رياضيات
الذكاء الاصطناعي

من الأسس الرياضية إلى أحدث النظريات

مرجع أكاديمي شامل

تسعة أجزاء · أربعة وخمسون فصلاً · مئات النظريات والأمثلة

م/أحمد صالح المغز

تأليف

الطبعة الأولى

المحتويات

I الأسس الرياضية ١

١ المنطق الرياضي، نظرية المجموعات، وأسس البرهان ٣

٢ الفضاءات المتجهة، الاستقلال الخطي، والهندسة الداخلية ٤١

٣ المصفوفات والتحويلات الخطية ٧٩

٤ القيم الذاتية، تحليل القيم المفردة (SVD)، وتحليل المصفوفات ١١٧

٥ النواظم (Norms)، المسافات، ومتراجحات المصفوفات ٢١١

٦ التحليل العددي والاستقرار الحسابي ٢٩٣

II التفاضل والتكامل ٣٨٢

٧ النهايات والاتصال والتقارب ٣٨٤

٨ الاشتقاق وقواعده ٤٢٩

٩ التفاضل المصفوفي: اليعقوبية، الهِسّية، وقواعد السلسلة ٤٦٧

١٠ التكامل، نظرية القياس، وتكامل ليبيسغ–ستيلتjes ٥٠٣

١١ متفاضلة تايلور وتحليل الأخطاء ٥٤٤

١٢ المعادلات التفاضلية والنظم الديناميكية ٥٨٣

III الاحتمالات والإحصاء ٦٢٠

١٣ فضاءات الاحتمال وبُنى القياس ٦٢٢

١٤ المتغيرات العشوائية والتوزيعات القياسية ٦٥٩

١٥ المتوقّع، التباين، والمصفوفات الموجبة ٦٨٥

١٦ الاحتمال الشرطي المتقدّم، بايز، والحقول العشوائية ٧١١

١٧ متراجحات التركيز (Concentration Inequalities) ٧٣٩

١٨ الإستدلال الإحصائي وتقدير المعلمات (MLE) / (MAP) ٧٥٩

١٩ السلاسل الزمنية والعمليات العشوائية ٧٧٧

IV التحسين ٧٩٥

٢٠ التحسين غير المقيّد واختبارات الأمثلية ٧٩٧

٢١ التحسين المقيّد: KKT والثنائية ٨١٥

٢٢ التحسين المحدّب ونظرية الازدواج ٨٣٢

٢٣ خوارزميات التدرّج: SGD، الزخم، L-BFGS Adam، ٨٥٠

٢٤ التحسين على المتشعّبات (Riemannian Optimization) ٨٦٧

٢٥ التحسين التوزيعي والتحسين الأسود ٨٨٤

V نظرية المعلومات ٩٠٢

٢٦ الإنتروبيا، الإنتروبيا المشتركة، وكسب المعلومات ٩٠٤

٢٧ إنتروبيا التقاطع، تباعد KL، وتباعدات ف-ديفرجنس ٩٢١

٢٨ السعة، الترميز، ومبدأ الوصف الأقصر ٩٣٨

٢٩ الهندسة المعلوماتية وقياس فيشر ٩٥٦

VI نظرية التعلم الإحصائي ٩٨٥

٣٠ إطار التعلّم: ERM، SRM، والتحيز-التباين ٩٨٧

٣١ بُعد VC، متراجحات Rademacher، والتركيز ١٠١٤

٣٢ نظرية PAC والتعلّم القابل للتعلّم ١٠٤١

٣٣ الاستقرار الخوارزمي والتعميم ١٠٦٦

٣٤ حدود التعميم في الشبكات العميقة ١١٠٠

VII رياضيات الشبكات العصبية ١١٣٦

٣٥ البيرسيبترون، الشبكات الأمامية، ونظريات التقريب الشامل ١١٣٨

٣٦ الانتشار العكسي بوصفه تفاضلاً آلياً عكسياً ١١٦١

٣٧ الشبكات الالتفافية: الالتفاف، الطوبولوجيا، والتماثل ١١٨٢

٣٨ الشبكات المتكرّرة ورياضيات الزمن ١٢٠٢

٣٩ المحوّلات: الانتباه، الترميز الموضعيّ، والتعقيد ١٢٢١

٤٠ نواة التماس العصبية (Neural Tangent Kernel) ١٢٤٠

٤١ النماذج التوليدية (Generative Models) ١٢٦٠

٤٢ النقل الأمثل والمسافات المائية (Optimal Transport & Wasserstein) ١٢٧٩

VIII بنى متقدّمة ١٢٩٨

٤٣ نظرية الرسوم البيانية والشبكات العصبية البيانية ١٣٠٠

٤٤ التعلم التعزيزي: MDPs ومعادلات بيلمان وحدود العيّنات ١٣١٩

٤٥ نظرية الألعاب والتعلّم الاستراتيجي ١٣٣٨

٤٦ الطوبولوجيا وتحليل البيانات الطوبولوجي (TDA) ١٣٥٧

٤٧ نظرية الفئات والذكاء الاصطناعي التركيبي ١٣٧٥

٤٨ الهندسة التفاضلية في التعلّم: المتشعّبات والتمثيلات ١٣٩٣

IX المتسلسلات ومعالجة الإشارة ١٤١٢

٤٩ المتسلسلات: التقارب، المعايير، والدوال المولّدة ١٤١٤

٥٠ متسلسلة فوريه ونظرية التقريب ١٤٥٠

٥١ تحويل فوريه، العيّنات، ونظرية نيكويست–شانون ١٤٨٣

٥٢ التحليل الزمني-الترددي والمويجات ١٥١٨

٥٣ معالجة الإشارة الحديثة والتعلّم العميق على الإشارات ١٥٥١

٥٤ آفاق حديثة: إشارة الرسوم، المؤثّرات العصبية، والتمثيلات الضمنية ١٥٨٣

ا الفهرس الشامل ١٦١٦

ا مسرد المصطلحات ١٦٦٣

القسم I

الأسس الرياضية

نبذة عن هذا الجزء

قبل أن نسأل «كيف يتعلّم الحاسوب؟» لا بدّ من إتقان اللغة التي يُكتب بها الجواب. هذا الجزء يؤسّس تلك اللغة: من **المنطق والمجموعات** التي تصوغ المسألة، إلى **الفضاءات المتجهية** التي تسكنها البيانات، إلى **المصفوفات والتحويلات الخطية** التي تُنفَّذ بها كل عمليّة تعلّم عميقة فعليّاً، ثم **القيم الذاتية وتحليل SVD** التي تكشف البنية الكامنة، و**المعايير والمتراجحات** التي تضبط المسافات والأخطاء، وأخيراً **التحليل العددي** الذي يعلّمنا كيف يُنفَّذ كل ذلك على آلة محدودة الدقّة دون أن ينكسر الحساب. من يتقن هذا الجزء ملك مفردات الكتاب كله؛ كل فصلٍ لاحق سيستعير منه رمزاً أو متراجحة أو خدعة عدديّة. لا تقرأه قراءة سريعة: الأمثلة المحلولة فيه هي البذرة التي تنبت منها أمثلة الأجزاء الباقية. **فصول الجزء:** المنطق والمجموعات · الفضاءات المتجهية · المصفوفات والتحويلات الخطية · القيم الذاتية وSVD · المعايير والمتراجحات · التحليل العددي.

فصول هذا الجزء

- **الفصل 1.** المنطق الرياضي، نظرية المجموعات، وأسس البرهان
- **الفصل 2.** الفضاءات المتجهة، الاستقلال الخطي، والهندسة الداخلية
- **الفصل 3.** المصفوفات والتحويلات الخطية
- **الفصل 4.** القيم الذاتية، تحليل القيم المفردة (SVD)، وتحليل المصفوفات
- **الفصل 5.** النواظم (Norms)، المسافات، ومتراجحات المصفوفات
- **الفصل 6.** التحليل العددي والاستقرار الحسابي

المنطق الرياضي، نظرية المجموعات، وأسس البرهان

الشعار: «الذكاء الاصطناعي ليس سحراً؛ إنه حسابٌ على بنىً رمزية. والمنطق هو النحو الذي يُكتب به هذا الحساب.»

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. صياغة مسائل الذكاء الاصطناعي بلغة المنطق القضيوي والمجموعات.

٢. تطبيق **قوانين دي مورغان** لتبسيط الشروط المركّبة في الأنظمة الخبيرة والاستعلامات.

٣. استخدام **مبدأ الشمول والاستبعاب** في العدّ الاحتمالي وتغطية البيانات.

٤. بناء براهين صحيحة بـ **الاستقراء الرياضي** على خوارزميات التعلّم.

٥. استنتاج حدود دنيا مضمونة بـ **مبدأ الحمام** (وأثره في التعلّم والتجزئة).

٦. تركيب استدلالات آلية بـ **قواعد الاستدلال وقاعدة الاستيعاب**.

المتطلبات المسبقة

معرفة بحساب المجموعات الابتدائية. لا يُفترض أي معرفة مسبقة بالذكاء الاصطناعي.

خريطة الفصل

القسم	القانون/النظرية	عدد الأمثلة المحلولة
1.1	المنطق القضيوي والمجموعات — المفردات	—
2.1	قوانين دي مورغان	15
3.1	مبدأ الشمول والاستبعاد	15
4.1	مبدأ الاستقراء الرياضي	15
5.1	مبدأ الحمام (ديريكله)	15
6.1	قواعد الاستدلال والاستيعاب	15
7.1	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

Inclusion–Exclusion · Laws Morgan's De · Theory Set · Logic Predicate · Logic Propositional · Resolution · Rules Inference · Principle Pigeonhole · Induction Mathematical · Principle Solver SAT · Completeness · Soundness

1.1.1 القضية (Proposition)

القضية عبارة لغوية يمكن الحكم عليها بالصدق أو الكذب، ولا تحتمل الأمرين معاً.

$$P \in \{\text{True},\ \text{False}\} \equiv P \in \{1,\ 0\} \tag{1.0.1}$$

الرمز	المعنى	بديل برمجي
$P,\ Q,\ R$	قضايا (متغيّرات قضوية)	متغيّر منطقي bool
False / True	قيمتا الصدق	0 / 1
$\top$	الصدق الدائم (tautology)	true
$\bot$	الكذب الدائم (contradiction)	false
$\neg$	النفي (NOT)	!
$\wedge$	العطف (AND)	&&
$\vee$	الفصل الشامل (OR)	`
$\oplus$	الفصل الحصري (XOR)	^
$\rightarrow$	اللزوم المنطقي (IF...THEN)	fi
$\leftrightarrow$	التكافؤ (IFF)	==
$\equiv$	التكافؤ المنطقي الدائم	—
$\models$	اللزوم الدلالي (كل نموذج يُحقّق)	—
$\vdash$	اللزوم التركيبي (يُشتقّ بالقواعد)	—
Γ	مجموعة مقدمات (نظرية)	قاعدة معرفة
φ	صيغة (formula)	استعلام

تنبيه مهم: الفرق بين $\rightarrow$ و $\models$ جوهري في الذكاء الاصطناعي: $\psi \rightarrow \varphi$ صيغةٌ داخل المنطق، بينما $\Gamma \models \varphi$ **حكمٌ** على اللغة يقول: «كل نموذج يُحقّق Γ يُحقّق φ أيضاً». الأنظمة الخبيرة تعمل بـ $\Gamma \vdash \varphi$ (اشتقاق)، ونحن نريدها أن تكون أمينة أي $\Gamma \vdash \varphi \Rightarrow \Gamma \models \varphi$.

2.1.1 الرابط بين المنطق والمجموعات

كل قضية P تقابل مجموعة A_P هي «مجموعة العوالم/الحالات التي يكون فيها P صادقاً»:

$$A_P \ = \ \{\, \omega \in \Omega \ \mid \ P(\omega) = 1 \,\} \tag{2.0.1}$$

الرمز	المعنى
Ω	فضاء العيّنات/العوالم الممكنة (sample space)
ω	عالم/حالة مفردة
$\mid$	فاصل الشرط «بحيث أنّ»
$\in$	ينتمي إلى

ويقابل ذلك:

$$A_{P \wedge Q} = A_P \cap A_Q, \qquad A_{P \vee Q} = A_P \cup A_Q, \qquad A_{\neg P} = A_P^c = \Omega \setminus A_P \tag{3.0.1}$$

هذا «القاموس» هو ما يجعل قوانين المنطق وقوانين المجموعات وجهين لعملة واحدة.

3.1.1 لماذا يهمّ هذا الذكاء الاصطناعي؟

التطبيق	أين يظهر المنطق
تمثيل المعرفة (Knowledge Graphs)	حقائق ثلاثية + قواعد استدلال
التحقق الرسمي من النماذج (Model Checking)	صيغ زمنية على حالات النظام
محرّكات SAT/SMT	إرضاء صيغة قضيوية
الذكاء العصبي–الرمزي (Neuro-Symbolic)	تحويل القواعد إلى قيود في دالة الخسارة
أنظمة التوصية القائمة على القواعد	شروط مركّبة على سمات المستخدم
أمن السيبرانية (SIEM)	قواعد تنبيه متداخلة

صاغها: أوغستس دي مورغان (1806–1871). وهي اليوم حجر الأساس في تبسيط الدوائر الرقمية وتحويل الاستعلامات وتطبيع الصيغ في محرّكات SAT.

1.2.1 الصياغة الرسمية

الصيغة القضيوية:

$$\neg(P \wedge Q) \equiv (\neg P) \vee (\neg Q) \tag{1.1}$$

$$\neg(P \vee Q) \equiv (\neg P) \wedge (\neg Q) \tag{2.1}$$

الصيغة المجموعية:

$$\left(\bigcup_{i \in I} A_i\right)^c = \bigcap_{i \in I} A_i^c \tag{3.1}$$

$$\left(\bigcap_{i \in I} A_i\right)^c = \bigcup_{i \in I} A_i^c \tag{4.1}$$

الصيغة الكمّية (المنطق المحمول):

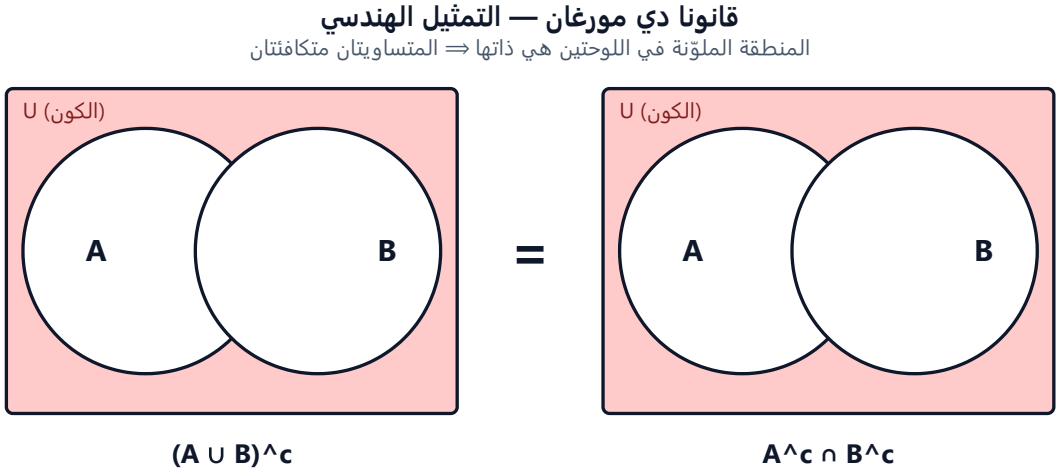
$$\neg\, \forall x\ P(x) \equiv \exists x\ \neg P(x) \tag{5.1}$$

$$\neg\, \exists x\ P(x) \equiv \forall x\ \neg P(x) \tag{6.1}$$

2.2.1 جدول الرموز والمعاملات (إلزامي)

الرمز	الاسم	المعنى الدقيق	ملاحظة تطبيقية
$\neg$	النفي (Negation)	يعكس قيمة الصدق: $0 \mapsto 1, 1 \mapsto 0$	بوابة NOT
$\wedge$	العطف (Conjunction)	صادق فقط إذا صدق الطرفان معاً	بوابة AND، تقابل $\cap$، وتقابل الضرب ab
$\vee$	الفصل (Disjunction)	صادق إذا صدق أحد الطرفين على الأقل	بوابة OR، تقابل $\cup$، وتقابل $a+b-ab$
$\equiv$	التكافؤ المنطقي	الصيغتان لهما جدول صدق متطابق	ليس عملية حسابية بل علاقة بين صيغتين
I	مؤشّر المجموعة (Index Set)	مجموعة الدلائل التي تُفهرس بها العائلة	قد تكون منتهية $\{1, \dots, n\}$ أو لانهائية
A_i	المجموعة رقم i	عنصر من عائلة المجموعات	في البرمجة: قائمة شروط
$\bigcup$	الاتحاد (Union)	كل ما ينتمي إلى **واحدة على الأقل**	OR" -ary$n$"
$\bigcap$	التقاطع (Intersection)	ما ينتمي إلى **كل** المجموعات معاً	AND" -ary$n$"
^{c} أو $\complement$	المتمّم (Complement)	$\Omega \setminus A$: كل ما ليس في A	على مستوى المجموعة NOT
$\forall$	كمّي شامل	«لكلّ»	حلقة all for
$\exists$	كمّي وجودي	«يوجد»	بحث حتى أول إصابة
$\setminus$	الطرح المجموعي	$A \setminus B = A \cap B^c$	«في A وليس في B»

3.2.1 الشكل الهندسي



شكل ١.١: *
قوانين دي مورغان

شكل (1.1): المنطقة الملوّنة (خارج كلا القرصين) هي متمّم الاتحاد في اللوحة اليسرى، وهي تقاطع المتمّمين في اليمنى. التساوي البصري هو البرهان الحدسي.

4.2.1 البرهان

البرهان الأول (بجدول الصدق) للقانون (1.1):

$(\neg P) \vee (\neg Q)$	$\neg Q$	$\neg P$	$\neg(P \wedge Q)$	$P \wedge Q$	Q	P
1	1	1	**1**	0	0	0
1	0	1	**1**	0	1	0
1	1	0	**1**	0	0	1
0	0	0	**0**	1	1	1

تطابق العمودين المُغلَّفين $\Longrightarrow$ التكافؤ.

البرهان الثاني (عنصري — يعمّم على أي عدد من المجموعات) للقانون (3.1):

نُثبت تساوي المجموعتين بإثبات تضمين مزدوج. ليكن x عنصراً في الكون Ω:

$$x \in \left(\bigcup_{i \in I} A_i\right)^c \iff x \notin \bigcup_{i \in I} A_i \iff \neg\big(\exists i \in I :\ x \in A_i\big) \iff \forall i \in I :\ x \notin A_i \iff \forall i \in I :\ x \in A_i^c$$

وإذن المجموعتان لهما العناصر ذاتها، فهما متساويتان. ■

5.2.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1.1-1): مرشّح البريد المزعج (Spam Filter)

المعطيات: قاعدة الحجب: «احجب الرسالة إذا احتوت كلمة «مجاني» و كان المرسل غير معروف». ليكن P = «الرسالة تحتوي «مجاني»»، Q = «المرسل غير معروف». المطلوب: صياغة شرط «الرسالة مقبولة» (أي لا تُحجب) بمفردات بسيطة، ثم حسابها إن كان $P = 1,\ Q = 0$.

الحل: الخطوة 1: شرط الحجب هو $P \wedge Q$. الخطوة 2: القبول هو نفي الحجب: $\neg(P \wedge Q)$. الخطوة 3: بتطبيق (1.1): $\neg(P \wedge Q) \equiv (\neg P) \vee (\neg Q)$. الخطوة 4: بالقيم المعطاة: $\neg P = 0$، $\neg Q = 1 \Longrightarrow 0 \vee 1 = 1$.

النتيجة: الرسالة **مقبولة** لأن المرسل معروف، حتى مع وجود كلمة «مجاني». الربط بالذكاء الاصطناعي: تجميع القواعد في مرشّح بيزي أو شجرة قرار يستلزم تحويل النفي إلى OR على المتمّمات لتقليل عدد الفروع.

مثال (2.1-1): كاميرا مراقبة ذكية

المعطيات: تبدأ الكاميرا التسجيل إذا اكتشفت حركة **أو** سمعت صوتاً غير اعتيادي: $H \vee S$. المطلوب: متى **لا** تسجّل؟

الحل: الخطوة 1: عدم التسجيل $= \neg(H \vee S)$. الخطوة 2: بتطبيق (2.1): $\neg(H \vee S) \equiv (\neg H) \wedge (\neg S)$. الخطوة 3: الترجمة: «لا حركة و لا صوت غير اعتيادي».

النتيجة: السكون التام بصرياً وسمعياً. الربط بالذكاء الاصطناعي: هذه الصيغة هي exactly ما يفعله دمج المستشعرات (sensor fusion) عند تعطيل الإنذارات الكاذبة، وتحويل OR إلى AND على النفي يقلّل استهلاك الطاقة على أجهزة الحافة.

مثال (3.1-1): السيارة ذاتية القيادة — قرار السير

المعطيات: تتوقف السيارة إذا وُجد مطر غزير و ضباب كثيف معاً: $M \wedge F$. تتوفّر مستشعرات تعطي $M = 1$ (مطر) و $F = 0$ (لا ضباب). المطلوب: هل تتوقف؟

الحل: الخطوة 1: التوقف $= M \wedge F = 1 \wedge 0 = 0$. الخطوة 2: السير $= \neg(M \wedge F) = (\neg M) \vee (\neg F) = 1 \vee 0 = 1$.

النتيجة: **تسير**. يكفي انتفاء شرط واحد. الربط بالذكاء الاصطناعي: أنظمة السلامة تبني «شجرة أعطال» (Fault Tree) حيث بوابة AND تعني «كل الأسباب معاً»، وبوابة OR تعني «أي سبب»؛ دي مورغان هو أداة التحويل بين شجرة الأعطال وشجرة النجاح.

مثال (4.1-1): استعلام قاعدة بيانات SQL

المعطيات: استعلام: SELECT * FROM users WHERE NOT (city='Cairo') AND (age>=18). جدول

فيه 1000 صف، منهم 300 في القاهرة، ومن هؤلاء 200 عمرهم ≥ 18. المطلوب: إعادة كتابة الاستعلام وعدد النتائج.

الحل: الخطوة 1: بالقانون (1.1): (A NOT) (NOT $\iff$ B) AND (NOT OR A) (B. الخطوة 2: أي WHERE age<18 OR city<>'Cairo'. الخطوة 3: عدد المستوفين للأصل: 200 − 300... لا، بل: المستثنون $|A \cap B| = 200$ =. الخطوة 4: النتائج $1000 - 200 = 800$ =.

النتيجة: 800 صف. الربط بالذكاء الاصطناعي: محسّنات الاستعلام (query optimizers) تُطبّق دي مورغان لدفع النفي إلى الداخل (push-down negation) فتستطيع استخدام الفهارس بدلاً من مسح الجدول كاملاً.

مثال (1.1-5): بوابة NAND العالمية

المعطيات: بوابة NAND تُعطي $\overline{a \cdot b}$. المطلوب: إثبات أن NAND وحدها تكفي لبناء NOT و OR.

الحل: الخطوة 1: $\text{NOT(a)} = \overline{a \cdot a} = \text{NAND(a,a)}$. الخطوة 2: بدي مورغان: $\overline{a \cdot b} = \bar{a} + \bar{b}$. الخطوة 3: إذن $a + b = \overline{\bar{a} \cdot \bar{b}} = \text{NAND}(\text{NAND(a,a)}, \text{NAND(b,b)})$. الخطوة 4: التحقق: إذا $a = 1, b = 0 \Longrightarrow$ NAND(1,1)=0، NAND(0,0)=1 $\Longrightarrow$ NAND(0,1)=1 = $a + b$ ✓.

النتيجة: NAND عالمية (Universal Gate). الربط بالذكاء الاصطناعي: كل دارة حسابية في المعالج — ومنها معجّلات الشبكات العصبية (TPU/NPU) — تُبنى من بوابة عالمية واحدة؛ هذا أصل « universality » في الحوسبة.

مثال (1.1-6): تشخيص طبي مركّب

المعطيات: يُشخَّص المريض بمتلازمة أيضية إذا كان اختبارا T_1 و T_2 **كلاهما** إيجابياً. نتائج مريض: T_1 = إيجابي، T_2 = سلبي. المطلوب: صياغة «المريض سليم بالنسبة للمتلازمة» بعدد أقل من العمليات الطبية.

الحل: الخطوة 1: التشخيص $T_1 \wedge T_2$ =. الخطوة 2: النفي $\neg T_1 \vee \neg T_2$ =. الخطوة 3: بما أن $\neg T_2 = 1$ (سلبي يكفي)، فالنتيجة 1 =.

النتيجة: سليم؛ ولا حاجة لإجراء اختبار ثالث. الربط بالذكاء الاصطناعي: «الاختبار المتسلسل» (sequential testing) في الأنظمة الخبيرة الطبية يعتمد على هذا: نفي AND يُقيَّم من اليسار لليمين ويتوقّف عند أول شرط منتفي (short-circuit evaluation).

مثال (1.1-7): نظام التحكم بالوصول RBAC

المعطيات: يُمنح المستخدم الصلاحية إذا كان (مديراً أو مالكاً للمورد) و (حسابه نشطاً): $(D \vee O) \wedge N$. مستخدم: $D = 0,\ O = 1,\ N = 1$. المطلوب: متى يُرفض الوصول؟

الحل: الخطوة 1: الرفض $\neg\big((D \vee O) \wedge N\big)$ =. الخطوة 2: بدي مورغان على AND الخارجي: $\neg(D \vee O) \vee \neg N$. الخطوة 3: ثم على OR الداخلي: $(\neg D \wedge \neg O) \vee \neg N$ =. الخطوة 4: للمستخدم: $\neg(D \vee O) = \neg(0 \vee 1) = 0$، $\neg N = 0 \Longrightarrow$ رفض 0 =.

النتيجة: يُمنح الوصول لأنه مالك وحسابه نشط. الربط بالذكاء الاصطناعي: محرّكات السياسات (OPA, XACML) تُطبّع الصيغ إلى DNF عبر دي مورغان قبل التقييم، فتصبح المقارنة بين السياسات مسألة تطابق أنماط.

مثال (1.1-8): محرّك بحث متقدّم

المعطيات: استعلام المستخدم: (python NOT java) OR (java في فهرس من 50,000 مستند: 12,000 فيها python، 9,000 فيها java، 3,000 فيهما معاً. المطلوب: عدد النتائج.

الحل: الخطوة 1: بالقانون (2.1): $\neg(P \vee J) \equiv \neg P \wedge \neg J$. الخطوة 2: عدد المستندات التي فيها أحدهما على الأقل (اتحاد): $|P \cup J| = 12{,}000 + 9{,}000 - 3{,}000 = 18{,}000$. الخطوة 3: النتائج $50{,}000 - 18{,}000 = 32{,}000$.

النتيجة: 32,000 مستند. الربط بالذكاء الاصطناعي: الفهارس المقلوبة (inverted indexes) تخزّن لكل مصطلح قائمة نشر (posting list)؛ الاستعلامات المنفية تُنفَّذ كتكملة لاتحاد القوائم، ودي مورغان يحوّل AND على النفي إلى طرح من الكون.

مثال (1.1-9): كشف احتيال بطاقة ائتمانية

المعطيات: يُرفع إنذار إذا كانت العملية (بمبلغ كبير و من بلد جديد) أو (خارج ساعات النشاط المعتادة): $(B \wedge N) \vee O$. عملية: $B = 1,\ N = 0,\ O = 0$. المطلوب: هل هناك إنذار؟ ثم اكتب صيغة «العملية طبيعية».

الحل: الخطوة 1: الإنذار $(1 \wedge 0) \vee 0 = 0 \vee 0 = 0$. الخطوة 2: الطبيعية $\neg\big((B \wedge N) \vee O\big) =$. الخطوة 3: بدي مورغان المزدوج: $\neg O \wedge (\neg B \vee \neg N) = \neg(B \wedge N) \wedge \neg O =$. الخطوة 4: بالقيم: $(\neg 1 \vee \neg 0) \wedge \neg 0 = 1 \wedge (0 \vee 1)$.

النتيجة: العملية طبيعية (مبلغ كبير لكن بلد معتاد وزمن معتاد). الربط بالذكاء الاصطناعي: تحويل القواعد إلى DNF يسمح بحساب «درجة الخطورة» كدرجة انتماء ضبابية (fuzzy membership) بدل المنطق الثنائي، باستبدال $\wedge$ بـ min و $\vee$ بـ max.

مثال (1.1-10): منظّم حرارة ذكي (IoT)

المعطيات: يُشغّل المكيّف إذا كانت (الحرارة > 28 أو الرطوبة > 70) و (أحدٌ في الغرفة): $C = (H \vee R) \wedge P$. الحالة: $H = 1,\ R = 0,\ P = 1$. المطلوب: حالة التشغيل، وصيغة الإيقاف.

الحل: الخطوة 1: $C = (1 \vee 0) \wedge 1 = 1$. الخطوة 2: الإيقاف $\neg C = \big(\neg H \wedge \neg R\big) \vee \neg P =$. الخطوة 3: بالقيم: $(0 \wedge 1) \vee 0 = 0$.

النتيجة: المكيّف **يعمل**. الربط بالذكاء الاصطناعي: في المنطق الضبابي تُستبدل الصيغة بـ $\mu_C = \min(\max(\mu_H, \mu_R),\ \mu_P)$؛ ودي مورغان يبقى صالحاً مع min/max لأنهما توزّعان على بعضهما.

مثال (1.1-11): التحقق الرسمي بمنطق الزمن الخطي (LTL)

المعطيات: الخاصية المطلوبة: «ليس صحيحاً أن النظام يبقى في الانتظار إلى الأبد و لا يستجيب أبداً»: $\neg(\Box W \wedge \Box\neg R)$. المطلوب: صياغة مكافئة مناسبة لخوارزمية التحقق.

الحل: الخطوة 1: بتطبيق (1.1): $\neg(\Box W \wedge \Box\neg R) \equiv \neg\Box W \vee \neg\Box\neg R$. الخطوة 2: $\neg\Box\varphi \equiv \Diamond\neg\varphi$ (نفي «دائماً» = «أحياناً النفي»). الخطوة 3: إذن الصيغة $\Diamond\neg W \vee \Diamond R =$. الخطوة 4: المعنى: «سيخرج من الانتظار في وقت ما، أو سيستجيب في وقت ما».

النتيجة: صيغة «أخيراً» (liveness) بدل «دائماً» (safety)، وهي أسهل للتحقق الآلي. الربط بالذكاء الاصطناعي: محرّكات التحقق (NuSMV, SPIN) تحوّل الخاصية إلى أوتوماتا Büchi؛ دي مورغان على مستوى $\Box/\Diamond$ هو نفسه على مستوى $\forall/\exists$ في (5.1)–(6.1).

مثال (1.1-12): روبوت مستودع — تجنّب العوائق

المعطيات: يتوقف الروبوت إذا وُجد عائق أمامه و عائق خلفه (محاصر): $F \wedge B$. قراءات الليدار: $F = 0,\ B = 1$. المطلوب: هل يتحرك؟ وإلى أين؟

الحل: الخطوة 1: التوقف $0 = 1 \wedge 0 =$. الخطوة 2: الحركة ممكنة $\neg(F \wedge B) = \neg F \vee \neg B = 1 \vee 0 = 1 =$. الخطوة 3: بما أن $\neg F = 1$ (لا عائق أمام)، الاتجاه الآمن هو **الأمام**.

النتيجة: يتحرك للأمام. الربط بالذكاء الاصطناعي: في التخطيط الرمزي، فضاء الحالة يُمثَّل بـ صيغة/BDD قضيوية؛ ودي مورغان هو عملية «التبديل بين تمثيل الحالات الممنوعة والسموحة بها».

مثال (1.1-13): نظام توصية بالمحتوى

المعطيات: يُستبعد الفيديو إذا كان (قصيراً و قديم): $O \wedge S$. مكتبة 200,000 فيديو، 40,000 قصير، 25,000 قديم، 12,000 قصير وقديم. المطلوب: عدد الفيديوهات المؤهّلة للترشيح.

الحل: الخطوة 1: المستبعد $|S \cap O| = 12{,}000 =$. الخطوة 2: المؤهّل $\neg(S \wedge O) \equiv \neg S \vee \neg O = \Longrightarrow$ العدد $200{,}000 - 12{,}000 =$. الخطوة 3: $188{,}000 =$.

النتيجة: 188,000 فيديو مؤهّل. الربط بالذكاء الاصطناعي: حساب «المرشّحين» (candidate generation) خطوةٌ تمهيدية لكل نموذج توصية؛ ودي مورغان يحوّل قواعد الاستبعاد من AND إلى OR على النفي فتُنفَّذ بفهارس بتّية (bitset OR).

مثال (1.1-14): شبكة عصبية تنفّذ بوابة NAND

المعطيات: بيرسيبترون: $y = \mathbb{1}[w_1x_1 + w_2x_2 + b \geq 0]$، بـ $w_1 = w_2 = -2,\ b = 3$. المطلوب: أي بوابة منطقية يُنفّذها؟ وما علاقتها بدي مورغان؟

الحل: الخطوة 1: جدول الحساب:

- $(0,0)$: $0+0+3=3\geq 0 \Longrightarrow y=1$
- $(1,0)$: $-2+3=1\geq 0 \Longrightarrow y=1$
- $(0,1)$: $-2+3=1\geq 0 \Longrightarrow y=1$
- $(1,1)$: $-4+3=-1<0 \Longrightarrow y=0$ الخطوة 2: هذا جدول $\neg(x_1\wedge x_2)$ = NAND. الخطوة 3: بدمج ثلاث خلايا NAND (انظر مثال 1.1-5) نبني OR و NOT.

النتيجة: خلية عصبية واحدة بوزن سالب وانحياز موجب = بوابة NAND = أساس أي حاسوب. الربط بالذكاء الاصطناعي: هذا هو المثال الأدنى على أن الشبكة العصبية **تحسب صيغاً منطقية**؛ ومنه تبدأ نظريات التقريب الشامل (الفصل 35).

مثال (1.1-15): جدولة تدريب على خوادم GPU

المعطيات: يُؤجَّل التدريب إذا كان (كلّ الـ GPU مشغولة **أو** الذاكرة المتوفّرة < 8GB): $G\vee M$. الحالة: $G=0$ (يوجد GPU فارغة)، $M=1$ (ذاكرة قليلة). المطلوب: هل يُشغَّل التدريب؟

الحل: الخطوة 1: التأجيل $=0\vee 1=1 \Longrightarrow$ **يُؤجَّل**. الخطوة 2: التشغيل $=\neg(G\vee M)=\neg G\wedge\neg M=1\wedge 0=0$. الخطوة 3: لتشغيله نحتاج تحرير ذاكرة (جعل $M=0$).

النتيجة: يبقى مؤجَّلاً حتى تُحرَّر الذاكرة. الربط بالذكاء الاصطناعي: موزّعات الأعمال (Kubernetes schedulers) تُقيّم «قيوداً» (predicates) بهذا الشكل؛ وتحويلها إلى DNF بدي مورغان يجعل فحص الجدوى متوازياً.

6.2.1 أخطاء شائعة

الخطأ	الصواب
$\neg(P\wedge Q)=\neg P\wedge\neg Q$	**العملية تتغيّر** — $\neg P\vee\neg Q$
نسيان قوسين: $\neg P\vee Q$ بدل $\neg(P\vee Q)$	القوسان يحدّدان مجال النفي
اعتبار $\neg\forall x P(x)\equiv\forall x\neg P(x)$	$\exists x\,\neg P(x)$
الخلط بين $\equiv$ (تكافؤ صيغ) و $\leftrightarrow$ (رابط داخل صيغة)	$\leftrightarrow$ رابط، $\equiv$ علاقة خارجية

الفكرة: إذا جمعت أحجام المجموعات «شمولاً» تكون قد حسبت التقاطعات مرتين، ف«تستبعدها»؛ ثم تكون قد استبعدت التقاطع الثلاثي أكثر من اللازم، فتعيده ... حتى تصل إلى دقة تامّة.

1.3.1 الصياغة الرسمية

مجموعتان:

$$|A\cup B| \;=\; |A|+|B|-|A\cap B| \tag{7.1}$$

ثلاث مجموعات:

$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C| \tag{8.1}$$

الصيغة العامة:

$$\left|\bigcup_{i=1}^{n} A_i\right| = \sum_{i=1}^{n} |A_i| - \sum_{1\le i<j\le n} |A_i \cap A_j| + \sum_{1\le i<j<k\le n} |A_i \cap A_j \cap A_k| - \cdots + (-1)^{n+1} \left|\bigcap_{i=1}^{n} A_i\right| \tag{9.1}$$

أو بصيغة مختصرة:

$$\left|\bigcup_{i=1}^{n} A_i\right| = \sum_{\emptyset \neq S \subseteq \{1,\ldots,n\}} (-1)^{|S|+1} \left|\bigcap_{i \in S} A_i\right| \tag{'9.1}$$

الصيغة الاحتمالية (تُستخدم أكثر في الذكاء الاصطناعي):

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \sum_{i} \mathbb{P}(A_i) - \sum_{i<j} \mathbb{P}(A_i \cap A_j) + \cdots + (-1)^{n+1} \mathbb{P}\left(\bigcap_{i} A_i\right) \tag{10.1}$$

متّراجحة بونفيروني (نتيجة مباشرة — تُستخدم لتقدير الحدود العليا والدنيا):

$$\sum_{i=1}^{n} \mathbb{P}(A_i) - \sum_{i<j} \mathbb{P}(A_i \cap A_j) \le \mathbb{P}\left(\bigcup_{i} A_i\right) \le \sum_{i=1}^{n} \mathbb{P}(A_i) \tag{11.1}$$

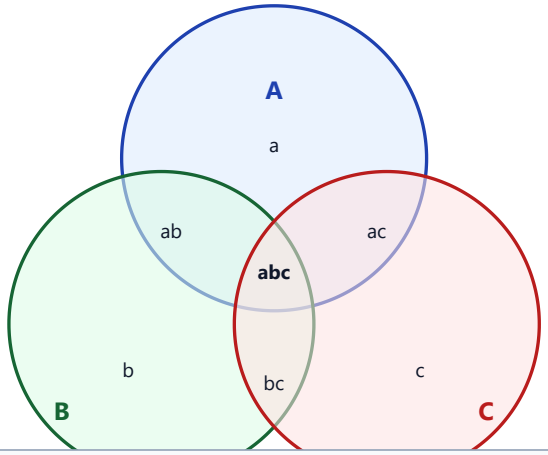
2.3.1 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
$\lvert A\rvert$	العدد الأصلي (Cardinality)	عدد عناصر المجموعة المنتهية	في الاحتمال يقابلها $\mathbb{P}(A)$
$\cup$	الاتحاد	«واحدة على الأقل»	$\vee$ منطقياً
$\cap$	التقاطع	«الكل معاً»	$\wedge$ منطقياً
$S \subseteq \{1,\ldots,n\}$	مجموعة فرعية من الدلائل	كل اختيار لمؤشّرات	عددها $2^n - 1$ حدّاً
$(-1)^{\lvert S\rvert+1}$	إشارة التصحيح	زوجي $\Rightarrow$ سالب، فردي $\Rightarrow$ موجب	سبب تسمية «الاستبعاد»
$\mathbb{P}(\cdot)$	الاحتمال	قياسٌ مجموعه 1 على Ω	انظر الفصل 13
$\sum_{i<j}$	مجموع على أزواج مرتّبة	عدد الحدود $\binom{n}{2}$	—
$\binom{n}{k}$	التوافيق	عدد اختيار k من n	$\frac{n!}{k!(n-k)!}$
في (11.1) $\le$	متّراجحة	حدّان: أدنى وأعلى	تُسمّى حدود بونفيروني

3.3.1 الشكل الهندسي

شكل (2.1): المنطقة abc (مثلث الوسط) تُحسب ثلاث مرات في $|A|+|B|+|C|$، وتُطرح ثلاث مرات في حدود الأزواج، فتُعاد مرة واحدة في الحدّ الأخير $\Rightarrow$ صافي مرة واحدة.

مبدأ الشمول والاستبعاد (ثلاث مجموعات)



$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|$$

شكل (1.2): كل منطقة تُحسب مرة واحدة بالضبط بعد التصحيح

شكل ٢.١: *
مبدأ الشمول والاستبعاد

4.3.1 البرهان (طريقة العدّ المزدوج)

لتكن x عنصراً يقع في **بالضبط** k مجموعة من المجموعات $A_1, \ldots, A_n$ (حيث $1 \le k \le n$). عدد المرات التي يُحسب بها x في الطرف الأيمن من (9.1):

$$N(x) = \binom{k}{1} - \binom{k}{2} + \binom{k}{3} - \cdots + (-1)^{k+1}\binom{k}{k} = \sum_{j=1}^{k} (-1)^{j+1}\binom{k}{j}$$

من ذي الحدين (نظرية نيوتن):

$$\sum_{j=0}^{k} (-1)^j \binom{k}{j} = (1-1)^k = 0 \implies \sum_{j=1}^{k} (-1)^{j+1}\binom{k}{j} = \binom{k}{0} = 1$$

أي أن كل عنصر في الاتحاد يُحسب **مرة واحدة بالضبط**، وكل عنصر خارج الاتحاد ($k = 0$) يُحسب صفر مرة. فالطرفان متساويان. ■

5.3.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-2.1): طلاب ولغات برمجة

المعطيات: 120 طالباً؛ 70 يعرفون Python (A)، 55 يعرفون Java (B)، 30 يعرفون الاثنتين. المطلوب: من لا يعرف أيّاً منهما؟

الحل: الخطوة 1: $|A \cup B| = 70 + 55 - 30 = 95$. الخطوة 2: الخارج $= 120 - 95 = 25$.

النتيجة: 25 طالباً. الربط بالذكاء الاصطناعي: حساب «حجم السوق/الفئة المستهدفة» لمهارات نموذجية؛ نفس الحساب يُستخدم لتقدير حجم «مجموعة البيانات المفيدة» عند دمج مصادر متعدّدة.

مثال (1.2-2): ثلاثة أعراض وتشخيص

المعطيات: 1000 مريض: حمّى $|F| = 400$، سعال $|C| = 350$، ضيق نفس $|D| = 200$؛ $|F \cap C| = 150$، $|F \cap D| = 80$، $|C \cap D| = 60$، $|F \cap C \cap D| = 30$. المطلوب: كم مريضاً لديه عرضٌ واحد على الأقل؟

الحل: الخطوة 1: المجموع الفردي $= 400 + 350 + 200 = 950$. الخطوة 2: طرح الأزواج $= 950 - (150 + 80 + 60) = 950 - 290 = 660$. الخطوة 3: إضافة الثلاثي $= 660 + 30 = 690$.

النتيجة: 690 مريضاً (69%). الربط بالذكاء الاصطناعي: في أنظمة الفرز (triage) يحدّد هذا «معدّل التفعيل» لقاعدة مركّبة، وهو ما يضبط حساسية النموذج مقابل عبء العمل السريري.

مثال (1.2-3): وسوم المستندات في محرّك بحث

المعطيات: 5000 مستند: موسومة ML = 1200، Vision = 900، NLP = 800؛ ML∩Vision = 300، ML∩NLP = 250، Vision∩NLP = 150؛ الثلاثي = 70. المطلوب: عدد المستندات الموسومة بواحد على الأقل من الوسوم الثلاثة.

الحل: الخطوة 1: $2900 = 800 + 900 + 1200$. الخطوة 2: $2200 = 2900 - 700 = 2900 - (300 + 250 + 150)$. الخطوة 3: $2270 = 2200 + 70$.

النتيجة: 2270 مستنداً $\Longrightarrow$ 2730 مستنداً غير موسومة. الربط بالذكاء الاصطناعي: تقدير حجم «الشريحة المؤهّلة للتدريب» (eligible training pool) قبل بناء مجموعة بيانات متعددة الوسوم.

مثال (1.2-4): صلاحيات المستخدمين في نظام سحابي

المعطيات: 800 مستخدم: لهم دور read = 600، write = 350، admin = 100؛ read∩write = 300، read∩admin = 90، write∩admin = 60؛ الثلاثي = 55. المطلوب: كم مستخدم له صلاحية واحدة على الأقل؟

الحل: الخطوة 1: $1050 = 600 + 350 + 100$. الخطوة 2: $600 = 1050 - 450 = 1050 - (300 + 90 + 60)$. الخطوة 3: $655 = 600 + 55$.

النتيجة: 655 من 800 (81.9%). الربط بالذكاء الاصطناعي: حساب «سطح الهجوم» (attack surface) = اتحاد الصلاحيات، هذا مقياس مباشر للمخاطر في أمن الذكاء الاصطناعي.

مثال (1.2-5): تغطية شبكة مستشعرات زراعية

المعطيات: حقل مقسّم لمناطق، ثلاثة مستشعرات تغطي: A: 40%، B: 35%، C: 30% من المساحة، التداخلات: 12%، 10%، 8%؛ الثلاثي 4%. المطلوب: نسبة المساحة المغطّاة فعلياً.

الحل: الخطوة 1: $105 = 30 + 35 + 40$. الخطوة 2: $75 = 105 - 30 = 105 - (12 + 10 + 8)$. الخطوة 3: $79 = 75 + 4$.

النتيجة: 79% مغطّاة، 21% ثغرة blind). الربط بالذكاء الاصطناعي: «تغطية فضاء الميزات» spot) بمجموعة نماذج/نماذج أولية (prototypes)؛ الثغرة تُترجم إلى مناطق قرار غير موثوقة (out-of-distribution).

مثال (١.٢-6): احتمال فشل نظام موزّع

المعطيات: خدمة من 3 وحدات، احتمالات الفشل المستقلّة: 0.02، 0.03، 0.05. المطلوب: احتمال فشل الخدمة (فشل وحدة واحدة على الأقل).

الحل: الخطوة 1: بالاستقلال: $\mathbb{P}(A \cap B) = 0.02 \times 0.03 = 0.0006$؛ وبالمثل 0.001 و 0.0015؛ والثلاثي 0.00003. الخطوة 2: بالصيغة (١.١٠): $0.10 = 0.02 + 0.03 + 0.05$. الخطوة 3: $0.0969 = 0.10 - 0.0031 = 0.10 - (0.0006 + 0.001 + 0.0015)$. الخطوة 4: $+0.00003 = 0.09693$.

النتيجة: $\approx$ 9.٦٩% (مقابل 10% بالتقدير الساذج). الربط بالذكاء الاصطناعي: موثوقية أنظمة الاستدلال الموزّعة (inference clusters)؛ الفرق بين 10% و 9.٦٩% يحدّد عدد النسخ الاحتياطية المطلوبة.

مثال (١.٢-7): تصفية مجموعة تدريب بشروط متعددة

المعطيات: 100,000 صورة، معايير القبول: وضوح (A) 82,000، توازن لوني (B) 74,000، خلوّ من الوسوم الخاطئة (C) 90,000، الأزواج: 62,000 و 75,000 و 68,000، الثلاثي 58,000. المطلوب: حجم مجموعة التدريب النهائية.

الحل: الخطوة 1: $82{,}000 + 74{,}000 + 90{,}000 = 246{,}000$. الخطوة 2: $246{,}000 - 205{,}000 = 41{,}000 = -(62{,}000 + 75{,}000 + 68{,}000)$. الخطوة 3: $+58{,}000 = 99{,}000$.

النتيجة: 99,000 صورة صالحة (99%). الربط بالذكاء الاصطناعي: هذه هي «بوابة الجودة» في خطوط إنتاج البيانات (data pipelines)؛ إهمال حدّ التقاطع الثلاثي هو سبب كلاسيكي لانكماش مفاجئ في حجم البيانات.

مثال (١.٢-8): عدد مستندات تحتوي كلمة في استعلام OR

المعطيات: فهرس 2,000,000 مستند، «ذكاء» في 40,000، «اصطناعي» في 55,000، «تعلّم» في 30,000، الأزواج 8,000 و 5,000 و 6,000، الثلاثي 1,500. المطلوب: عدد نتائج الاستعلام ذكاء OR اصطناعي OR تعلّم.

الحل: الخطوة 1: $125{,}000 = 30{,}000 + 55{,}000 + 40{,}000$. الخطوة 2: $106{,}000 = 125{,}000 - 19{,}000 = -(8{,}000 + 5{,}000 + 6{,}000)$. الخطوة 3: $+1{,}500 = 107{,}500$.

النتيجة: 107,500 مستند. الربط بالذكاء الاصطناعي: حساب «التذكير الأقصى» (recall ceiling) لمحرّك استرجاع؛ لا يمكن لنموذج إعادة ترتيب (reranker) أن يتجاوز هذا السقف.

مثال (١.٢-9): تداخل مجموعات الميزات بين نموذجين

المعطيات: نموذج A يستخدم 500 ميزة، نموذج B يستخدم 400، نموذج C يستخدم 300، التداخل $A \cap B = 200$، $A \cap C = 120$، $B \cap C = 90$، الثلاثي 50. المطلوب: عدد الميزات الفريدة المستخدمة في المجموعة بأكملها.

الحل: الخطوة 1: $1200 = 300 + 400 + 500$. الخطوة 2: $790 = 1200 - 410 = (90 + 120 + 200)-$. الخطوة 3: $840 = 50+$.

النتيجة: 840 ميزة فريدة. الربط بالذكاء الاصطناعي: حساب «بصمة الذاكرة» عند دمج نماذج (model ensemble) أو عند حساب تعقيد استخراج الميزات في خط الأنابيب.

مثال (1.2-10): حملة تسويقية متعددة القنوات

المعطيات: 200,000 عميل وصلتهم: بريد (E) 90,000، رسالة نصية (S) 70,000، إشعار تطبيق (P) 60,000، الأزواج 30,000 و 25,000 و 20,000، الثلاثي 10,000. المطلوب: عدد العملاء الذين وصلتهم رسالة واحدة على الأقل، ونسبة الوصول الفريد.

الحل: الخطوة 1: $220{,}000 = 60{,}000 + 70{,}000 + 90{,}000$. الخطوة 2: $145{,}000 = 220{,}000 - 75{,}000 = (30{,}000 + 25{,}000 + 20{,}000)-$. الخطوة 3: $155{,}000 = 10{,}000+$. الخطوة 4: النسبة $= 155{,}000/200{,}000 = 77.5\%$.

النتيجة: 155,000 عميل (77.5%). الربط بالذكاء الاصطناعي: «الوصول الفريد» (unique reach) هو المقياس الحقيقي لتأثير الحملة؛ الجمع الساذج 220,000 يضخّم النتيجة بنسبة 42%.

مثال (1.2-11): تغطية الاختبارات البرمجية لنموذج

المعطيات: ثلاثة أجنحة اختبار تغطي وحدات الكود: 65%، 55%، 45%؛ تداخل الأزواج 30%، 25%، 20%؛ الثلاثي 15%. المطلوب: التغطية الإجمالية.

الحل: الخطوة 1: $165 = 45 + 55 + 65$. الخطوة 2: $90 = 165 - 75 = (20 + 25 + 30)-$. الخطوة 3: $105 = 15+$.

النتيجة: 105% $\Longrightarrow$ غير ممكن $\Longrightarrow$ البيانات متناقضة؛ الحد الأقصى 100%، فيلزم تصحيح القياسات (أو أن «النسبة المئوية» ليست من الكلّ نفسه). الربط بالذكاء الاصطناعي: **درس منهجي:** نتيجة خارج $[0, 1]$ لأي احتمال/نسبة تعني خطأً في المعطيات أو انتهاكاً لافتراض الاستقلال؛ هذه «فحص صحّة» (sanity check) إلزامي قبل أي حساب احتمالي.

مثال (1.2-12): خلاف نماذج في مجموعة (Ensemble Disagreement)

المعطيات: ثلاثة مصنّفات على 10,000 عيّنة: أخطاء A = 800، B = 900، C = 750؛ يتفق اثنان على الخطأ: $|A \cap B| = 300$، $|A \cap C| = 250$، $|B \cap C| = 280$؛ ثلاثتهم يخطئ معاً = 120. المطلوب: كم عيّنة يخطئ فيها واحد على الأقل؟

الحل: الخطوة 1: $2450 = 750 + 900 + 800$. الخطوة 2: $1620 = 2450 - 830 = (280 + 250 + 300)-$. الخطوة 3: $1740 = 120+$.

النتيجة: 1740 عيّنة (17.4%) $\Longrightarrow$ دقة التصويت بالأغلبية أعلى بكثير من أي نموذج مفرد. الربط بالذكاء الاصطناعي: هذا هو التفسير الكمّي لسبب نجاح التجميع (ensembling): الخطأ المشترك (التقاطعات) يجب أن يكون صغيراً مقابل الأخطاء الفردية.

مثال (1.2-13): تصنيف متعدد الوسوم للصور

المعطيات: 50,000 صورة: «شخص» 22,000، «سيارة» 18,000، «مبنى» 15,000؛ الأزواج 7,000 و 5,000 و 4,000؛ الثلاثي 2,000. المطلوب: عدد الصور التي تحمل وسماً واحداً على الأقل، ثم عدد الصور بوسم واحد **بالضبط**.

الحل: الخطوة 1: الاتحاد $= |A| + |B| + |C| - 2(|A \cap B| + |A \cap C| + |B \cap C|) + 3|A \cap B \cap C| = 55{,}000 - 2(16{,}000) + 3(2{,}000) = 55{,}000 - 32{,}000 + 6{,}000 = 29{,}000$. الخطوة 2: وسم واحد بالضبط $= 41{,}000 - 2{,}000 - 16{,}000 + 2{,}000 = 55{,}000$. الخطوة 3: النتيجة: 41,000 بوسم واحد على الأقل؛ 29,000 بوسم واحد بالضبط. الربط بالذكاء الاصطناعي: التمييز بين «once» و«at least once» هو نفسه التمييز بين دقة الوسم الجزئي والكلي (exact vs. partial) في تقييم التصنيف متعدد الوسوم.

مثال (1.2-14): تعداد n-grams في نموذج لغة

المعطيات: متن من 1,000,000 كلمة؛ القاموس يحتوي 60,000، 400,000 uni-gram، 900,000 bi-gram، tri-gram. التداخل بين الفئات (كمجموعات أنماط) مهمل، لكن داخلياً: 1,200,000 نمطاً محتملاً. استخدم حدّ بونفيروني لتقدير احتمال أن يظهر نمطٌ غير مرئي في الاختبار إن كان احتمال ظهور كل نمط 10^{-8} وعدد الأنماط 10^6. المطلوب: حدّ أعلى لاحتمال الظهور.

الحل: الخطوة 1: ليكن A_i حدث «النمط i يظهر». الخطوة 2: بحدّ الاتحاد (بونفيروني الأعلى من (1.1.11)): $\mathbb{P}(\cup A_i) \le \sum_i \mathbb{P}(A_i)$. الخطوة 3: $= 10^6 \times 10^{-8} = 10^{-2} = 0.01$. النتيجة: احتمال $\le 1\%$. الربط بالذكاء الاصطناعي: حدّ الاتحاد (union bound) هو الأداة الأساسية في حدود التعميم في التعلّم الآلي: $\mathbb{P}(\text{أيّ انحراف}) \le \sum \mathbb{P}(\text{انحراف}_i)$. سيظهر مجدداً في الفصل 32.

مثال (1.2-15): كشف تهديدات عبر ثلاثة مستشعرات أمنية

المعطيات: ثلاثة كواشف: إنذارات كاذبة في 5%، 4%، 6% من الأحداث (n = 100,000 حدث يومياً)؛ تكرار الإنذار الكاذب المشترك: 1,000 و 1,200 و 900 والثلاثي 200. المطلوب: عدد الإنذارات الكاذبة المميّزة يومياً.

الحل: الخطوة 1: $6{,}000 + 4{,}000 + 5{,}000 = 15{,}000$. الخطوة 2: $15{,}000 - (1{,}000 + 1{,}200 + 900) = 11{,}900$. الخطوة 3: $12{,}100 = 200 + 3{,}100$.

النتيجة: 12,100 إنذاراً كاذباً يومياً بدل 15,000 بالحساب الساذج (تحسّن 19%). الربط بالذكاء الاصطناعي: إزالة التكرار (deduplication) في أنظمة SIEM يقلّل «إرهاق التنبيهات» (alert fatigue) وهو شرط عملي لاعتماد نموذج كشف التهديدات.

6.3.1 أخطاء شائعة

الخطأ	الصواب
نسيان إضافة التقاطع الثلاثي في (8.1)	الإشارة تتناوب دائماً: $+, -, +, -, \ldots$
تطبيق الصيغة على أحداث غير منتهية العدد	الصيغة مشروطة بنهاية n (والا تقارب)
استخدام $\lvert A\rvert + \lvert B\rvert$ لحدثين غير متنافيين	غير متنافية $\Rightarrow$ اطرح التقاطع
نتيجة > 1 للاحتمال أو $> 100\%$ لنسبة	يُعيد فحص المعطيات فوراً

الفكرة: لإثبات صواب عبارة عن كل عدد طبيعي، يكفي إثبات أمرين: أنها صحيحة عند البداية، وأن صحتها عند أي مرتبة تستلزم صحتها عند المرتبة التالية. السلسلة كلها تسقط كقطع الدومينو.

1.4.1 الصياغة الرسمية

الاستقراء الضعيف (Weak Induction): لتكن $P(n)$ عبارةً قضيوية معرّفة على $n \geq n_0$.

$$\Big[\, P(n_0) \text{ صادقة} \,\Big] \;\wedge\; \Big[\forall k \geq n_0 :\; P(k) \Rightarrow P(k+1)\Big] \;\Longrightarrow\; \Big[\forall n \geq n_0 :\; P(n)\Big] \tag{12.1}$$

بصيغة مختصرة:

$$\big(P(n_0) \wedge \forall k \geq n_0\, [P(k) \to P(k+1)]\big) \;\Longrightarrow\; \forall n \geq n_0\; P(n) \tag{'12.1}$$

الاستقراء القوي (Strong Induction):

$$\Big[\forall k \geq n_0 :\; \big(\forall j :\; n_0 \leq j < k \Rightarrow P(j)\big) \Rightarrow P(k)\Big] \;\Longrightarrow\; \Big[\forall n \geq n_0 :\; P(n)\Big] \tag{13.1}$$

الاستقراء البنيوي (Structural Induction) — أساس إثبات صحة خوارزميات الأشجار والرسوم:

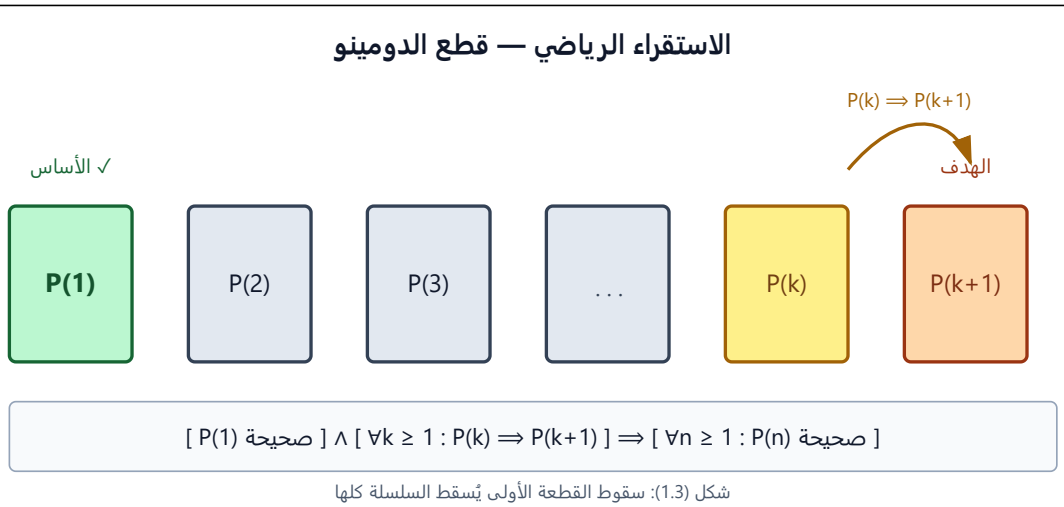
$$\Big[\, P \text{ كل ورقة تحقق} \,\Big] \;\wedge\; \Big[\forall v \text{ عقدة} :\; \big(\forall c \text{ من أبناء } v :\; P(c)\big) \Rightarrow P(v)\Big] \;\Longrightarrow\; \forall \text{عقدة} :\; P \tag{14.1}$$

مبدأ حسن الترتيب (Well-Ordering) — المبدأ المكافئ للاستقراء:

$$\forall S \subseteq \mathbb{N},\; S \neq \emptyset \;\Longrightarrow\; \exists m \in S :\; \forall s \in S,\; m \leq s \tag{15.1}$$

2.4.1 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
$P(n)$	العبارة/الخاصية	دالة من $\mathbb{N}$ إلى $\{0,1\}$	« predicate »
n_0	الأساس (Base)	أول قيمة تُثبت يدوياً	غالباً 0 أو 1
k	مرتبة الاستقراء	القيمة المفترض صحتها	«فرضية الاستقراء» IH
$\Rightarrow$	اللزوم	إذا صدق الأيسر صدق الأيمن	منطقياً $\to$
$\wedge$	العطف	كلا الشرطين معاً	شرطان لازم ومجموعهما كافٍ
$\mathbb{N}$	الأعداد الطبيعية	$\{0,1,2,\ldots\}$ أو $\{1,2,\ldots\}$ حسب الاصطلاح	—
$j < k$	—	كل المراتب السابقة	الفرق الجوهري بين (12.1) و (13.1)
S	مجموعة فرعية من $\mathbb{N}$	في (15.1): مجموعة «القيم المضادّة»	أداة البرهان بالتناقض
$T(n)$	دالة التكلفة	زمن/عدد عمليات خوارزمية على مدخل حجمه n	في تحليل التعقيد
$O(\cdot)$	ترميز O الكبير	حدّ أعلوى مقاربي	انظر الفصل 6



شكل (1.3): سقوط القطعة الأولى يُسقط السلسلة كلها

شكل ٣.١: *
الاستقراء الرياضي

3.4.1 الشكل الهندسي

شكل (3.1): القطعة الخضراء $(P(1))$ هي الأساس؛ السهم الذهبي هو خطوة الاستقراء؛ وكل قطعة لاحقة تسقط بالضرورة.

4.4.1 البرهان (من مبدأ حسن الترتيب)

نُثبت (12.1) بالتناقض. لنفرض أن المقدّمة صادقة ولكن التيجة كاذبة، أي توجد قيمة لا تحقق P. عرّف:

$$S \;=\; \{\, n \geq n_0 \mid P(n) \text{ كاذبة} \,\} \neq \emptyset$$

بمبدأ حسن الترتيب (15.1) يوجد أصغر عنصر $m = \min S$.

- $m \neq n_0$ لأن $P(n_0)$ صادقة (الأساس).
- إذن $m > n_0$، فليكن $k = m - 1 \geq n_0$. وبما أن m هو الأصغر في S، فـ $k \notin S$، أي $P(k)$ صادقة.
- بخطوة الاستقراء: $P(k) \Rightarrow P(k+1) = P(m)$، أي $P(m)$ صادقة $\Longrightarrow m \notin S$. تناقض.

إذن $S = \emptyset$، أي $P(n)$ صادقة لكل $n \geq n_0$. ■

5.4.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-3.1): عدد المعلمات في شبكة عصبية متعددة الطبقات

المعطيات: شبكة ذات L طبقات كاملة الاتصال؛ الطبقة ℓ فيها n_ℓ عصبون، ومدخلاتها $n_{\ell-1}$. معلمات الطبقة: $n_\ell n_{\ell-1} + n_\ell$ (أوزان + انحيازات). المطلوب: إثبات بالاستقراء أن العدد الكلي $W_L = \sum_{\ell=1}^{L}(n_\ell n_{\ell-1} + n_\ell)$.

الحل: الخطوة 1 (الأساس $L = 1$): $W_1 = n_1 n_0 + n_1$ ✓ بديهي. الخطوة 2 (الفرض): نفترض $W_k = \sum_{\ell=1}^{k}(n_\ell n_{\ell-1} + n_\ell)$. الخطوة 3 (الخطوة): بإضافة الطبقة $k+1$: $W_{k+1} = W_k + (n_{k+1}n_k + n_{k+1}) = \sum_{\ell=1}^{k+1}(n_\ell n_{\ell-1} + n_\ell)$ ✓. الخطوة 4: بالاستقراء، الصيغة صحيحة لكل $L \geq 1$.

النتيجة: عدد المعلمات الكلي يُحسب بجمع طبقي بسيط. الربط بالذكاء الاصطناعي: هذه الصيغة هي نواة أي حاسبة لمعلمات النموذج (مثل torchsummary)؛ وتُستخدم لتقدير بصمة الذاكرة قبل التدريب.

مثال (1.3-2): صحة خوارزمية ترتيب بالإدراج (Insertion Sort)

المعطيات: $P(n)$ = «الترتيب بالإدراج يُرتّب أي مصفوفة طولها n تصاعدياً». المطلوب: إثبات بالاستقراء.

الحل: الخطوة 1 (الأساس $n = 1$): مصفوفة من عنصر واحد مرتّبة دائماً ✓. الخطوة 2 (الفرض): الخوارزمية ترتّب أي مصفوفة طولها k. الخطوة 3 (الخطوة): لمصفوفة طولها $k + 1$: تُرتَّب أول k عناصر (بالفرض)، ثم يُدخل العنصر $(k+1)$ في موضعه الصحيح بمقارنات متتالية نحو اليسار حتى يصبح المقطع كله مرتّباً. الخطوة 4: إذن $P(k+1)$ صحيحة.

النتيجة: الخوارزمية صحيحة لكل n. الربط بالذكاء الاصطناعي: هذه هي حجة «المتغيّر الثابت للحلقة» (loop invariant)؛ وهي نفس بنية برهان صحة خوارزميات التعلّم المتكرّرة (مثل تحديثات mini-batch).

مثال (1.3-3): عدد الحواف في شجرة

المعطيات: شجرة (رسم بياني متصل بلا دورات) ذات n عقدة. المطلوب: إثبات أن عدد الحواف $E(n) = n-1$.

الحل: الخطوة 1 (الأساس $n = 1$): عقدة واحدة، صفر حواف، $1 - 1 = 0$ ✓. الخطوة 2 (الفرض): كل شجرة بـ k عقدة لها $k-1$ حافة. الخطوة 3 (الخطوة): شجرة بـ $k+1$ عقدة تحتوي ورقة (عقدة درجتها 1)؛ بإزالتها نحصل على شجرة بـ k عقدة لها $k-1$ حافة (بالفرض)، وإرجاع الورقة يضيف حافة واحدة: $(k-1)+1 = k = (k+1)-1$ ✓.

النتيجة: $E = n - 1$ لكل شجرة. الربط بالذكاء الاصطناعي: أشجار القرار تحتوي $n-1$ حافة داخلية، والصيغة تحدّد عدد الاختبارات اللازمة لتصنيف عيّنة: عمق الشجرة لا عدد حوافها.

مثال (1.3-4): عدد العقد في شجرة ثنائية كاملة

المعطيات: شجرة ثنائية كاملة ارتفاعها h (الجذر عند المستوى 0). المطلوب: إثبات أن عدد العقد $N(h) = 2^{h+1} - 1$.

الحل: الخطوة 1 (الأساس $h = 0$): عقدة واحدة، $2^1 - 1 = 1$ ✓. الخطوة 2 (الفرض): $N(k) = 2^{k+1} - 1$. الخطوة 3 (الخطوة): شجرة ارتفاع $k+1$ = جذر + شجرتان ارتفاع كلٍّ منهما k: $N(k+1) = 1 + 2N(k) = 1 + 2(2^{k+1} - 1) = 1 + 2^{k+2} - 2 = 2^{k+2} - 1 = 2^{(k+1)+1} - 1$ ✓.

النتيجة: $N = 2^{h+1} - 1$. الربط بالذكاء الاصطناعي: في أشجار القرار، عدد الأوراق $\leq 2^{h+1}$؛ ومنه يُستنتج حدّ «بُعد VC» لأشجار القرار، وهو ما يضبط سعة النموذج.

مثال (1.3-5): تعقيد خوارزمية الدمج (Merge Sort)

المعطيات: $T(1) = 1$، وللدخل بحجم n: $T(n) = 2T(n/2) + n$. المطلوب: إثبات بالاستقراء أن $T(n) = n\log_2 n + n$ عندما يكون n قوةً للعدد 2.

الحل: الخطوة 1 (الأساس $n = 1$): $T(1) = 1 = 0 + 1 = 1 \cdot \log_2 1 + 1$ ✓. الخطوة 2 (الفرض): $T(k) = k\log_2 k + k$. الخطوة 3 (الخطوة، بوضع $n = 2k$): $T(2k) = 2T(k) + 2k = 2(k\log_2 k + k) + 2k = 2k\log_2 k + 4k$. ونحسب الهدف: $2k\log_2(2k) + 2k = 2k(\log_2 k + 1) + 2k = 2k\log_2 k + 4k$ ✓ متطابقان.

النتيجة: $T(n) = \Theta(n\log n)$. الربط بالذكاء الاصطناعي: فرز النتائج في أنظمة الاسترجاع وترتيب أهمية العيّنات (importance sampling) يعملان بهذا التعقيد، وهو أيضاً تعقيد حساب الانتباه الكامل على تسلسل طويل بعد تقنيات التقريب.

مثال (1.3-6): نمو متتالية فيبوناتشي

المعطيات: $F_0 = 0,\ F_1 = 1,\ F_{n+1} = F_n + F_{n-1}$. المطلوب: إثبات $F_n \geq \varphi^{n-2}$ لكل $n \geq 2$ حيث $\varphi = \frac{1+\sqrt{5}}{2} \approx 1.618$.

الحل: الخطوة 1 (الأساس $n = 2$): $F_2 = 1 \geq \varphi^0 = 1$ ✓. الخطوة 2 (الفرض القوي): نفترض الصحة لكل j بحيث $2 \leq j \leq k$. الخطوة 3 (الخطوة): $F_{k+1} = F_k + F_{k-1} \geq \varphi^{k-2} + \varphi^{k-3} = \varphi^{k-3}(\varphi + 1)$. وبما أن $\varphi^2 = \varphi + 1$: $= \varphi^{k-3}\varphi^2 = \varphi^{k-1} = \varphi^{(k+1)-2}$ ✓.

النتيجة: نموٌّ أُسّي بأساس φ. الربط بالذكاء الاصطناعي: الاستقراء **القوي** ضروري هنا لأن الحدّ يعتمد على حدّين سابقين؛ نفس البنية تظهر في حدود تقلّص التدرّج على T خطوة (حيث يعتمد الخطأ على خطأين سابقين).

مثال (1.3-7): متراجحة برنولي

المعطيات: $x > -1$ حقيقي، $n \in \mathbb{N}$. المطلوب: إثبات $(1+x)^n \geq 1 + nx$.

الحل: الخطوة 1 (الأساس $n = 0$): $1 \geq 1$ ✓. الخطوة 2 (الفرض): $(1+x)^k \geq 1 + kx$. الخطوة 3 (الخطوة): $(1+x)^{k+1} = (1+x)^k(1+x) \geq (1+kx)(1+x) = 1 + (k+1)x + kx^2 \geq 1 + (k+1)x$ لأن $kx^2 \geq 0$ ✓.

النتيجة: المتراجحة صحيحة لكل n. الربط بالذكاء الاصطناعي: تُستخدم في إثبات أن تراكم الأخطاء النسبية في ضرب طبقات الشبكة يبقى مضبوطاً، وفي تحليل تضخّم/تلاشي التدرّج $(1+\varepsilon)^L$.

مثال (1.3-8): صحة خوارزمية إقليدس للقاسم المشترك الأكبر

المعطيات: $\gcd(a, b) = \gcd(b,\ a \bmod b)$. المطلوب: إثبات توقّف الخوارزمية وصحّتها بالاستقراء على عدد الخطوات.

الحل: الخطوة 1 (الأساس): إذا كان $b = 0$ فالخوارزمية تُعيد a وهو $\gcd(a,0)$ ✓. الخطوة 2 (الفرض): الخوارزمية صحيحة لكل مدخل يتطلّب k خطوة. الخطوة 3 (الخطوة): لمدخل (a,b) يتطلّب $k+1$ خطوة: الخطوة الأولى تُحوّله إلى $(b, a \bmod b)$ مع $a \bmod b < b$، فينخفض الطرف الثاني انخفاضاً صارماً، فالمدخل الجديد يتطلّب k خطوة (بالفرض صحيح)، وبخاصية $\gcd(a,b) = \gcd(b, a \bmod b)$ تكون النتيجة صحيحة ✓.

النتيجة: الخوارزمية صحيحة وتتوقّف. الربط بالذكاء الاصطناعي: أي خوارزمية تكرارية تحتاج **دالة تنازلية** (variant function) لإثبات التوقّف؛ في التعلّم العميق هذه الدالة هي دالة الخسارة، وشرط «تناقص كافٍ» هو شرط التقارب.

مثال (1.3-9): عدد المجموعات الفرعية

المعطيات: مجموعة S فيها n عنصراً. المطلوب: إثبات أن عدد المجموعات الفرعية $|2^S| = 2^n$.

الحل: الخطوة 1 (الأساس $n = 0$): $S = \emptyset$ لها مجموعة فرعية واحدة، $2^0 = 1$ ✓. الخطوة 2 (الفرض): مجموعة بـ k عنصر لها 2^k مجموعة فرعية. الخطوة 3 (الخطوة): لمجموعة بـ $k+1$ عنصر: نثبّت عنصراً s، المجموعات الفرعية التي لا تحتوي s = 2^k (مجموعات فرعية للباقي)، والتي تحتوي s = 2^k (كل واحدة مضافة إليها s). المجموع $= 2^k + 2^k = 2^{k+1}$ ✓.

النتيجة: 2^n مجموعة فرعية. الربط بالذكاء الاصطناعي: فضاء البحث في اختيار الميزات (feature selection) حجمه 2^n $\Longrightarrow$ مسألة صعبة-NP $\Longrightarrow$ هذا هو مبرّر البحث الجشع والاسترخاء المحدّب (مثل Lasso).

مثال (1.3-10): صحة الانتشار العكسي عبر L طبقة

المعطيات: شبكة $f = f_L \circ f_{L-1} \circ \cdots \circ f_1$؛ الخطأ المعكوس $\delta_\ell = \frac{\partial \mathcal{L}}{\partial z_\ell}$. المطلوب: إثبات صحة علاقة التكرار $\delta_\ell = (W_{\ell+1}^\top \delta_{\ell+1}) \odot \sigma'(z_\ell)$ لكل ℓ.

الحل: الخطوة 1 (الأساس $\ell = L$): $\delta_L = \nabla_{\hat{y}} \mathcal{L} \odot \sigma'(z_L)$ يُحسب مباشرة من دالة الخسارة ✓. الخطوة 2 (الفرض): $\delta_{\ell+1}$ صحيحة. الخطوة 3 (الخطوة): بقاعدة السلسلة على $z_{\ell+1} = W_{\ell+1}\sigma(z_\ell) =: z_{\ell+1}$ $\delta_\ell = \left(\frac{\partial z_{\ell+1}}{\partial z_\ell}\right)^\top \delta_{\ell+1} = \left(W_{\ell+1}\,\mathrm{diag}(\sigma'(z_\ell))\right)^\top \delta_{\ell+1} = (W_{\ell+1}^\top \delta_{\ell+1}) \odot \sigma'(z_\ell)$ ✓. الخطوة 4: بالاستقراء التنازلي من L إلى 1، كل الطبقات صحيحة.

النتيجة: الانتشار العكسي يحسب التدرّج كاملاً بتكلفة O(تكلفة الانتشار الأمامي). الربط بالذكاء الاصطناعي: هذا البرهان هو قلب كل مكتبات التفاضل الآلي (PyTorch/TF)؛ وسيُبسَط في الفصل 36 بصيغة التفاضل الآلي العكسي.

مثال (1.3-11): عدد المعلمات في شبكة التفافية مع تجميع (Pooling)

المعطيات: L طبقات التفافية؛ الطبقة ℓ فيها c_ℓ قناة ونواة $k_\ell \times k_\ell$؛ التجميع لا يضيف معلمات. المطلوب: إثبات أن $W_L = \sum_{\ell=1}^{L} \left(c_{\ell-1} c_\ell k_\ell^2 + c_\ell\right)$.

الحل: الخطوة 1 (الأساس $L = 1$): $W_1 = c_0 c_1 k_1^2 + c_1$ ✓ (نواة لكل زوج قنوات + انحياز لكل قناة). الخطوة 2 (الفرض): الصيغة صحيحة لـ $L = m$. الخطوة 3 (الخطوة): $W_{m+1} = W_m + (c_m c_{m+1} k_{m+1}^2 + c_{m+1})$ (التجميع يضيف صفراً) = الصيغة عند $m+1$ ✓.

النتيجة: تُحسب المعلمات بجمع طبقي؛ التجميع لا يساهم. الربط بالذكاء الاصطناعي: تفسير جوهري لكون الشبكات الالتفافية «أخفّ» من الكاملة الاتصال: النواة مشتركة مكانياً (weight tying).

مثال (1.3.1-12): عدد المسارات في شبكة متبقّية (ResNet)

المعطيات: شبكة بـ L كتلة متبقّية؛ كل كتلة تضيف مساراً (skip connection)؛ ليكن M_L عدد مسارات المعلومات من المدخل إلى المخرج. المعطيات الإضافية: $M_1 = 2$ (مسار مباشر + مسار عبر الكتلة). المطلوب: إثبات $M_L = 2^L$.

الحل: الخطوة 1 (الأساس $L = 1$): $M_1 = 2 = 2^1$ ✓. الخطوة 2 (الفرض): $M_k = 2^k$. الخطوة 3 (الخطوة): عند الكتلة $(k+1)$ كل مسار سابق يتفرّع إلى مسارين (يعبر الكتلة أو يتجاوزها): $M_{k+1} = 2M_k = 2 \cdot 2^k = 2^{k+1}$ ✓.

النتيجة: 2^L مساراً؛ لـ $L = 50$ عدد ضخم. الربط بالذكاء الاصطناعي: هذا هو التفسير «كمجموعة غير صريحة من النماذج» (implicit ensemble) لنجاح ResNet؛ ويُستخدم في تحليل سلاسة سطح الخسارة.

مثال (1.3.1-13): صحة برمجة ديناميكية على سلسلة قرارات ماركوفية

المعطيات: MDP بأفق H؛ قيمة الحالة $V_h(s)$؛ معادلة بيلمان: $V_h(s) = \max_a \big[R(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_{h+1}(s')\big]$ مع $V_H(s) = 0$. المطلوب: إثبات بالاستقراء التنازلي أن الحلّ هو القيمة المثلى.

الحل: الخطوة 1 (الأساس $h = H$): لا مكافآت بعد الأفق، $V_H = 0$ مثلى ✓. الخطوة 2 (الفرض): V_{h+1} هي القيمة المثلى من الخطوة $h+1$ فصاعداً. الخطوة 3 (الخطوة): القيمة المثلى من h = أفضل مكافأة فورية + أفضل استمرار؛ وبمبدأ الأمثلية لبيلمان: $V_h(s) = \max_a[R + \gamma\, \mathbb{E}[V_{h+1}]]$، وبالفرض V_{h+1} مثلية $\Rightarrow$ V_h مثلية ✓. الخطوة 4: بالاستقراء التنازلي إلى $h = 0$ نحصل على السياسة المثلى.

النتيجة: البرمجة الديناميكية العكسية تعطي الحلّ الأمثل. الربط بالذكاء الاصطناعي: هذه البنية الاستقرائية هي أصل الخوارزميات الحديثة في التعلّم التعزيزي، (Q-learning، DQN، PPO) وستُفصَّل في الفصل 44.

مثال (1.3.1-14): تعقيد خوارزمية فرّق-تسد (Master Theorem) بحالة بسيطة

المعطيات: $T(n) = aT(n/b) + cn$ مع $a = b = 2$. المطلوب: إثبات $T(n) = O(n \log n)$ بالاستقراء.

الحل: الخطوة 1 (الأساس $n = 1$): $T(1) = c_0$ ثابت ✓. الخطوة 2 (الفرض): $T(m) \le C\, m \log_2 m$ لكل $m < n$. الخطوة 3 (الخطوة): $T(n) = 2T(n/2) + cn \le 2C\frac{n}{2}\log_2 \frac{n}{2} + cn = Cn(\log_2 n - 1) + cn = Cn\log_2 n - Cn + cn$. الخطوة 4: اختر $C \ge c$ $\Rightarrow$ $-Cn + cn \le 0$ $\Rightarrow$ $T(n) \le Cn \log_2 n$ ✓.

النتيجة: $T(n) \in O(n \log n)$. الربط بالذكاء الاصطناعي: تحليل تكلفة حساب الانتباه متعدد الرؤوس وخوارزميات FFT في الطبقات الالتفافية الطيفية يتبع هذا النمط بالضبط.

مثال (1.3.1-15): نمو حجم الذاكرة في تدريب متعدد الخطوات

المعطيات: تدريب SGD، الذاكرة المطلوبة بعد t خطوة M_t، عند كل خطوة يُخزَّن متوسط متحرّك لتدرّجات $G_t = \beta G_{t-1} + (1-\beta) g_t$ مع $G_0 = 0$. المطلوب: إثبات أن $G_t = (1-\beta)\sum_{i=1}^{t} \beta^{t-i} g_i$ بالاستقراء.

الحل: الخطوة 1 (الأساس $t = 1$): $G_1 = (1-\beta) g_1$ ✓. الخطوة 2 (الفرض): $G_k = (1-\beta)\sum_{i=1}^{k} \beta^{k-i} g_i$. الخطوة 3 (الخطوة): $G_{k+1} = \beta G_k + (1-\beta) g_{k+1} = \beta(1-\beta)\sum_{i=1}^{k} \beta^{k-i} g_i + (1-\beta) g_{k+1} = (1-\beta)\sum_{i=1}^{k+1} \beta^{(k+1)-i} g_i$ ✓.

النتيجة: المتوسط المتحرّك الأُسّي = مرجّح أُسّي لكل التدرّجات السابقة. الربط بالذكاء الاصطناعي: هذا هو جوهر محسّن Adam/RMSProp: الذاكرة ثابتة الحجم ($O(1)$) لكنها تُرمّز تاريخاً كاملاً — مثال كلاسيكي على هيكل بيانات استقرائي.

6.4.1 أخطاء شائعة

الخطأ	الصواب
إثبات الخطوة دون استخدام فرضية الاستقراء	ليست استقراءً؛ مناقشة مباشرة
الأساس عند $n = 1$ والخطوة من k إلى $k+1$ مع خاصية معرّفة من $n = 0$	طابق الأساس مع مجال التعريف
استخدام الاستقراء الضعيف حيث يلزم القوي (مثل فيبوناتشي)	استخدم (13.1) إذا كان الحدّ يعتمد على أكثر من سابق
«دائرة مفرغة»: افتراض النتيجة داخل الخطوة	الفرضية $P(k) \neq$ النتيجة $P(n)$

الفكرة: إذا وضعت n حمامة في m صندوقاً وكان $n > m$، فلا بدّ أن صندوقاً واحداً على الأقل يحوي أكثر من حمامة. بسيطة ... لكنها سلاحٌ قاطع في إثبات الاستحالة والحدود الدنيا.

1.5.1 الصياغة الرسمية

الصيغة الأساسية: إذا وُزّع n عنصراً على m صندوقاً فإن:

$$\exists\, j \in \{1, \dots, m\} : \quad |A_j| \;\geq\; \left\lceil \frac{n}{m} \right\rceil \tag{16.1}$$

الصيغة المتناظرة (صندوقٌ قليل الامتلاء):

$$\exists\, j \in \{1, \dots, m\} : \quad |A_j| \;\leq\; \left\lfloor \frac{n}{m} \right\rfloor \tag{17.1}$$

الصيغة المعمّمة (متوسط):

$$\frac{1}{m}\sum_{j=1}^{m} |A_j| \;=\; \frac{n}{m} \;\Longrightarrow\; \max_j |A_j| \;\geq\; \frac{n}{m} \;\geq\; \min_j |A_j| \tag{18.1}$$

الصيغة اللانهائية: إذا وُزّع عددٌ لانهائي من العناصر على عدد منتهٍ m من الصناديق، فصندوقٌ واحدٌ على الأقل لانهائي.

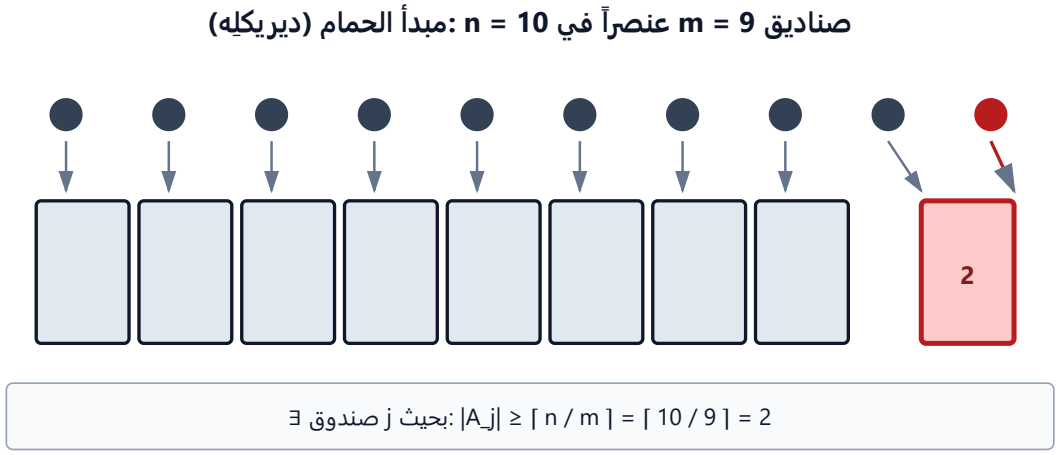
صيغة التصادم (مفتاح الـ hashing):

$$|\mathcal{K}| > |\mathcal{H}| \;\Longrightarrow\; \exists\, x \neq y \in \mathcal{K} :\; h(x) = h(y) \tag{19.1}$$

2.5.1 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
n	عدد العناصر (الحمامات)	حجم المجال	len(items)
m	عدد الصناديق	حجم المدى	num_buckets
A_j	الصندوق j	مجموعة العناصر التي وقعت في الصندوق j	—
$\lvert A_j \rvert$	عدد عناصر الصندوق j	«الامتلاء»	—
$\lceil x \rceil$	دالة السقف	أصغر عدد صحيح $\geq x$	ceil
$\lfloor x \rfloor$	دالة الأرضية	أكبر عدد صحيح $\leq x$	floor
$\exists$	كمّي وجودي	«يوجد»	ضمانة وجودية لا تُحدّد أيّ صندوق
$\max_j$ / $\min_j$	أعظمي/أدنى	عبر كل الصناديق	—
h	دالة تجزئة (Hash)	$h : \mathcal{K} \to \mathcal{H}$	—
$\mathcal{K}$	فضاء المفاتيح	كل المفاتيح الممكنة	قد يكون ضخماً
$\mathcal{H}$	فضاء الصناديق	قيم التجزئة الممكنة	حجمه m
$\Longrightarrow$	الاستلزام المنطقي	—	—

3.5.1 الشكل الهندسي



شكل (1.4): استحالة توزيع 10 عناصر على 9 صناديق دون تكرار

شكل ١.٤: *
مبدأ الحمام

شكل (4.1): عشرة عناصر وتسعة صناديق $\Longrightarrow$ صندوقٌ (المُلوّن) يحوي عنصرين.

4.5.1 البرهان

نُثبت (16.1) بالتناقض، ونُثبت (17.1) مباشرةً:

١. لو كان كل صندوق يحوي على الأكثر $\lceil n/m \rceil - 1$ عنصراً، لكان المجموع $m(\lceil n/m \rceil - 1) \leq$. وبما أن $\lceil n/m \rceil < n/m + 1$، فإن $m(\lceil n/m \rceil - 1) < m \cdot \frac{n}{m} = n$، أي المجموع $<$ — تناقض مع أن المجموع $n =$.

٢. ولو كان كل صندوق يحوي أكثر من $\lfloor n/m \rfloor$ (أي $\geq \lfloor n/m \rfloor + 1 > n/m$) لكان المجموع $> m \cdot \frac{n}{m} = n$ — تناقض أيضاً.

إذن الحدّان (16.1) و (17.1) محقّقان. ■

5.5.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-4.1): تصادم التجزئة في جدول ميزات (Hashing Trick)

المعطيات: مفردات لغوية بحجم 100,001 كلمة تُخزَّن في جدول تجزئة ذي 100,000 خانة. المطلوب: هل يمكن ضمان عدم التصادم؟

الحل: الخطوة 1: $m = 100{,}000 < 100{,}001 = n$. الخطوة 2: بـ (16.1): يوجد صندوق بـ $\geq \lceil 100001/100000 \rceil = 2$ عنصراً. الخطوة 3: إذن كلمتان مختلفتان لهما الخانة ذاتها.

النتيجة: تصادم حتمي (لا احتمالي). الربط بالذكاء الاصطناعي: هذا هو «خدعة التجزئة» (hashing trick) في نماذج اللغة؛ التصادم يقلّل الدقة قليلاً لكنه يوفّر الذاكرة بمرتبة كاملة — مقايضة مقبولة عملياً.

مثال (2-4.1): ضمان تكرار عيد ميلاد

المعطيات: غرفة فيها 367 شخصاً، السنة 366 يوماً (سنة كبيسة). المطلوب: هل يوجد شخصان لهما عيد الميلاد ذاته؟

الحل: الخطوة 1: $n = 367 > m = 366$. الخطوة 2: بـ (16.1): يومٌ واحد على الأقل يقابله $\geq \lceil 367/366 \rceil = 2$ شخص. الخطوة 3: إذن التكرار مضمون بنسبة 100%.

النتيجة: نعم، مضمون. الربط بالذكاء الاصطناعي: «مفارقة عيد الميلاد» الاحتمالية (احتمال > 50% عند 23 شخصاً) تُعمَّم إلى **تحليل احتمال التصادم** في التعلّم المتعادلاتي وفي تقدير حجم الذاكرة العشوائية (Bloom filters).

مثال (3-4.1): استحالة ضغط كل الملفات بدون فقد

المعطيات: كل ملفات الطول b بتّاً عددها 2^b؛ نُريد ضغطها كلها إلى أطوال $< b$. المطلوب: هل توجد خوارزمية ضغط تفقدية-صفرية تفعل ذلك؟

الحل: الخطوة 1: عدد الملفات الممكنة بطول أصغر من b هو $\sum_{i=0}^{b-1} 2^i = 2^b - 1$. الخطوة 2: $n = 2^b$ ملفاً في $m = 2^b - 1$ صندوقاً $\Rightarrow n > m$. الخطوة 3: بـ (16.1): ملفّان مختلفان لهما نفس الناتج $\Rightarrow$ فكّ الضغط لا يمكن أن يكون وحيداً.

النتيجة: **مستحيل رياضياً**؛ كل خوارزمية ضغط فعّالة تفقد البيانات على بعض المدخلات. الربط بالذكاء الاصطناعي: هذا هو البرهان المعلوماتي على أن «تعقيد كولموجوروف» غير قابل للحساب عموماً، وهو أساس مبدأ MDL في اختيار النماذج (الفصل 28).

مثال (4-4.1): كفاية عدد الخلايا العصبية لتغطية فضاء المدخلات

المعطيات: مصنّف ذو N خلية في الطبقة المخفية الأولى، ومدخلات ثنائية من $\{0,1\}^d$. المطلوب: إذا كان $N < 2^d$، هل يمكن أن تُفعّل كل خلية نمطاً فريداً لكل مدخل؟

الحل: الخطوة 1: عدد المدخلات الممكنة $n = 2^d$، عدد الأنماط المتاحة $m = 2^N$. الخطوة 2: بما أن $N < 2^d$ فـ $m = 2^N$... نحتاج مقارنة عدد الخلايا بأنماطها: كل خلية نمط تفعيل ثنائي $\Longrightarrow$ عدد الأنماط المميّزة $= 2^N$؛ ولتمييز 2^d مدخلاً نحتاج $2^N \geq 2^d$ أي $N \geq d$. الخطوة 3: بالمبدأ: إن كان $2^N < 2^d$ فمدخلان مختلفان لهما نمط التفعيل ذاته $\Longrightarrow$ لا يمكن التفريق بينهما.

النتيجة: شرط ضروري: $N \geq d$ خلية على الأقل لتمييز كل المدخلات الثنائية. الربط بالذكاء الاصطناعي: هذا أضعف أشكال «حدود السعة» (capacity bounds) التي ستظهر بصيغة قوية في نظرية التقريب الشامل وبُعد VC (الفصلان 31 و 35).

مثال (1.4-5): عدد العينات اللازمة لـ «سحق» صنف دوال

المعطيات: صنفٌ من الدوال يضم $|\mathcal{F}| = 2^{50}$ دالة؛ نريد أن نفرّق بينها ببيانات. المطلوب: كم عيّنة على الأقل نحتاج؟

الحل: الخطوة 1: كل عيّنة تُعطي إجابة ثنائية $\Longrightarrow$ n عيّنة تنتج 2^n نمط وسوم ممكناً. الخطوة 2: للتفريق بين 2^{50} دالة نحتاج $2^n \geq 2^{50}$ أي $n \geq 50$. الخطوة 3: إن كان $n = 49$ فبـ (1.6): توجد دالتان مختلفتان لهما نمط الوسوم ذاته على البيانات $\Longrightarrow$ لا نميزهما.

النتيجة: 50 عيّنة على الأقل. الربط بالذكاء الاصطناعي: هذه البذرة الأولى لمفهوم **بُعد VC**: عدد النقاط التي يمكن «سحقها» (shatter) يحدّد سعة الصنف، ومنه حدود التعميم.

مثال (1.4-6): جدولة مهام تدريب على خوادم

المعطيات: 10 مهام تدريب على 8 خوادم متطابقة. المطلوب: أثبت أن خادماً سيستقبل مهمتين على الأقل، وما أطول وقت انتظار مضمون إذا كانت كل مهمة تستغرق ساعة؟*

الحل: الخطوة 1: $n = 10$، $m = 8 \Longrightarrow \lceil 10/8 \rceil = 2$. الخطوة 2: خادمٌ ما يستقبل ≥ 2 مهمتين. الخطوة 3: زمنه $\geq$ ساعتين $\Longrightarrow$ أطول وقت إنجاز مضمون $\geq$ ساعتين (lower bound).

النتيجة: مهلة الضمان الأدنى: ساعتان. الربط بالذكاء الاصطناعي: حدود «نظرية الجدولة» (scheduling lower bounds) تحدّد زمن التدريب الموزّع ولا يمكن لأي خوارزمية ذكية تجاوزها.

مثال (1.4-7): لعنة الأبعاد — تغطية شبكة

المعطيات: نريد شبكةً على $[0,1]^d$ بخطوة 0.1 في كل بُعد؛ عدد خلايا الشبكة 10^d. عدد العيّنات المتاحة 1,000,000. المطلوب: ما أكبر بُعد d يمكن تغطيته (خلية واحدة لكل عيّنة على الأكثر)؟

الحل: الخطوة 1: التغطية الكاملة تتطلّب $n \geq m$ أي $10^d \geq 10^6$. الخطوة 2: $\Longrightarrow d \leq 6$. الخطوة 3: عند $d = 7$: $10^7 > 10^6$ $\Longrightarrow$ بـ (1.6) توجد خلية فارغة... بل العكس: خلايا أكثر من النقاط $\Longrightarrow$ **معظم الخلايا فارغة.**

النتيجة: التغطية ممكنة حتى 6 أبعاد فقط. الربط بالذكاء الاصطناعي: هذا هو التفسير الكمّي لـ «لعنة الأبعاد»: حجم

الفضاء ينمو أُسّياً مع d، فتصبح البيانات متناثرة، ومنه الحاجة إلى تقليل الأبعاد والتعلّم بتمثيلات (representation learning).

مثال (١.٤-8): كشف التكرار بـ MinHash

المعطيات: 5,000 مستند، عدد دلاء (buckets) التوقيع 1,000. المطلوب: هل يُتوقّع تصادم غير مرغوب (مستندان غير متشابهين في دلو واحد)؟

الحل: الخطوة 1: بتوزيع متوازن: متوسط الامتلاء $5000/1000 = 5$ مستند/دلو. الخطوة 2: بـ (١.١٦): يوجد دلو بـ ≥ 5 مستندات. الخطوة 3: كل دلو يحتوي أكثر من مستند $\Longrightarrow$ فحص أزواج داخل الدلو $\sum_j \binom{|A_j|}{2} =$.

النتيجة: التصادم حتمي؛ عدد الأزواج المفحوصة $1000 \cdot \binom{5}{2} = 10{,}000 \approx$ زوجاً. الربط بالذكاء الاصطناعي: في إزالة تكرار بيانات التدريب (deduplication) تُحدّد هذه الحسابات ميزانية الحوسبة قبل تدريب نموذج لغة كبير.

مثال (١.٤-9): تصادم في البحث بالجوار التقريبي (LSH)

المعطيات: 200,000 متجه عنصر في نظام توصية، جدول LSH ذو 50,000 دلو. المطلوب: متوسط عدد المرشحين لكل استعلام.

الحل: الخطوة 1: متوسط الامتلاء $200{,}000/50{,}000 = 4 =$. الخطوة 2: بـ (١.١٦): دلوٌ بـ ≥ 4 عناصر. الخطوة 3: بـ (١.١٧): دلوٌ بـ ≤ 4 عناصر.

النتيجة: ≈ 4 مرشّحين/استعلام بدل 200,000 (تسريع ×50,000). الربط بالذكاء الاصطناعي: LSH هو العمود الفقري للاسترجاع الكثيف السريع (FAISS) في أنظمة RAG الحديثة؛ المبدأ يضمن أن الاستعلام يفحص جزءاً ضئيلاً من الفهرس.

مثال (١.٤-10): درجات الطلاب

المعطيات: 101 طالب، الدرجات أعداد صحيحة من 0 إلى 100. المطلوب: أثبت أن طالبين لهما الدرجة ذاتها.

الحل: الخطوة 1: $n = 101$ طالب، $m = 101$ درجة ممكنة $(0 \ldots 100)$. الخطوة 2: هنا $n = m$ فلا يكفي المبدأ الأساسي؛ نفحص: إن كانت الدرجات كلها مختلفة فهي بالضبط $\{0, 1, \ldots, 100\}$. الخطوة 3: إن أضفنا طالباً واحداً $(n = 102)$ فـ $\lceil 102/101 \rceil = 2 \Longrightarrow$ تكرار حتمي. الخطوة 4: مع 101 طالب: التكرار **غير** مضمون لكنه ممكن.

النتيجة: الضمان يتطلّب 102 طالباً. الربط بالذكاء الاصطناعي: **درس منهجي:** تحقّق دائماً من صرامة المتراجحة ($<$ لا $\leq$ قبل تطبيق المبدأ؛ كثير من «البراهين» الخاطئة تنشأ من هذه النقطة وحدها.

مثال (١.٤-11): توزيع حزم الشبكة على صفوف المعالجة

المعطيات: 12,000 حزمة بيانات تُوجَّه إلى 256 صفاً (queue) في مُوجّه ذكي. المطلوب: كم حزمة في أكثر صفّ امتلاءً على الأقل؟

الحل: الخطوة 1: $\lceil 12000/256 \rceil = \lceil 46.875 \rceil = 47$. الخطوة 2: بـ (16.1): صفٌّ ما يحوي ≥ 47 حزمة. الخطوة 3: إن كانت السعة القصوى للصفّ 40 $\Longrightarrow$ فقدان حزم حتمي.

النتيجة: يلزم ≥ 47 سعة أو موازنة أفضل. الربط بالذكاء الاصطناعي: في أنظمة الاستدلال الموزّعة تحدّد هذه الحدود حجم «الوسادة» (buffer) لتجنّب فقدان الطلبات في أوقات الذروة.

مثال (12-4.1): تصادم التكميم (Quantization)

المعطيات: تكميم أوزان شبكة من 100,000 قيمة عشرية مختلفة إلى 256 مستوى (8-بت). المطلوب: كم قيمة تشترك في المستوى ذاته على الأقل؟

الحل: الخطوة 1: $n = 100{,}000$، $m = 256 \Longrightarrow \lceil 100000/256 \rceil = \lceil 390.625 \rceil = 391$. الخطوة 2: مستوىً ما يجمع ≥ 391 قيمةً مختلفةً تماماً.

النتيجة: خطأ التكميم لا يمكن أن يكون صفراً، ≥ 391 قيمة تندمج. الربط بالذكاء الاصطناعي: هذا يفسّر فقدان الدقة في quantization int8 للنماذج، ويبرّر تقنيات المعايرة (calibration) والمقاييس لكل قناة بدل مقياس عالمي.

مثال (13-4.1): توزيع النقاط في عناقيد k-means

المعطيات: 10,000 نقطة بيانات موزّعة على 20 عنقوداً. المطلوب: أثبت وجود عنقود بـ ≥ 500 نقطة، وآخر بـ ≤ 500 نقطة.

الحل: الخطوة 1: المتوسط $= 10000/20 = 500$. الخطوة 2: بـ (18.1): $\min_j |A_j| \leq 500 \leq \max_j |A_j|$. الخطوة 3: بـ (16.1): $\lceil 500 \rceil = 500 \Longrightarrow$ عنقود بـ ≥ 500.

النتيجة: لا يمكن أن تكون كل العناقيد متساوية تماماً إلا إذا كانت كلها 500 بالضبط. الربط بالذكاء الاصطناعي: عدم التوازن العنقودي يسبّب «انهيار العناقيد» في التعلّم الذاتي الإشراف (مثل SWAV و DINO)؛ ومنه تُصمَّم خسارة الإنتروبيا الموحّدة (unfiormity loss).

مثال (14-4.1): تصادم معرّفات الجلسات (Session IDs)

المعطيات: نظام يولّد معرّفات جلسة من 32 بتّاً، يُتوقّع 100,000 جلسة نشطة متزامنة. المطلوب: هل التصادم مضمون؟

الحل: الخطوة 1: عدد القيم الممكنة $m = 2^{32} = 4{,}294{,}967{,}296$. الخطوة 2: $n = 10^5 \ll m \Longrightarrow$ المبدأ لا يضمن تصادماً. الخطوة 3: لكن بصيغة عيد الميلاد الاحتمالية: $\mathbb{P}(\text{تصادم}) \approx 1 - e^{-n^2/(2m)} = 1 - e^{-10^{10}/(8.6\times10^9)} \approx 1 - e^{-1.16} \approx 0.69$.

النتيجة: التصادم غير مضمون حتمياً لكن احتماله $\approx 69\%$. الربط بالذكاء الاصطناعي: **مهم:** مبدأ الحمام يعطي **ضماناً حتمياً** فقط، وعند $n < m$ ننتقل إلى أدوات احتمالية (طريقة الاحتمال — Probabilistic Method، الفصل 17).

مثال (15-4.1): عناوين IP والأجهزة خلف NAT

المعطيات: موجّه NAT يملك 1 عنوان IP عام و 16,384 منفذاً متاحاً (2^{14}). المطلوب: كم جهازاً يمكن خدمته بضمان (اتصال لكل جهاز)؟

الحل: الخطوة 1: «الصناديق» = المنافذ، عددها $m = 16{,}384$. الخطوة 2: لضمان منفذ فريد لكل جهاز: $n \le m$. الخطوة 3: إن كان $n = 20{,}000$ جهازاً فـ $\lceil 20000/16384 \rceil = 2 \implies$ منفذٌ مشترك $\implies$ تصادم في ترجمة العناوين.

النتيجة: الحدّ المضمون 16,384 جهازاً متزامناً. الربط بالذكاء الاصطناعي: نفس البنية تظهر في «ميزانية المنافذ/السياقات» لخوادم الاستدلال التي تخدم آلاف النماذج؛ تجاوزها يعني تأخيراً أو رفضاً للطلبات.

6.5.1 أخطاء شائعة

الخطأ	الصواب
تطبيق المبدأ عند $n = m$	الشرط **الصارم** هو $n > m$
المبدأ «يقول أيّ صندوق»	المبدأ وجودي؛ لا يحدّد الصندوق
اعتباره أداة احتمالية	هو ضمان حتمي؛ الاحتمال حالة أخرى
نسيان أن الصناديق قد تكون فارغة	صيغة (17.1) تتعامل معها

الفكرة: الاستدلال الآلي ليس «تفكيراً» بل **تطبيقٌ متكرّر لقواعد محفوظة الصحة.** وقاعدة الاستيعاب (Resolution) وحدها تكفي — مع التناقض — لإثبات أي نتيجة في المنطق القضيوي. عليها بُنيت محرّكات SAT الحديثة.

1.6.1 الصياغة الرسمية

قواعد الاستدلال الأساسية (تُكتب كأُطر استدلال: ما فوق الخط مقدّمات، ما تحته نتيجة):

$$\textbf{MP:}\quad \frac{P,\qquad P \to Q}{Q} \tag{20.1}$$

$$\textbf{MT:}\quad \frac{\neg Q,\qquad P \to Q}{\neg P} \tag{21.1}$$

$$\textbf{HS:}\quad \frac{P \to Q,\qquad Q \to R}{P \to R} \tag{22.1}$$

$$\textbf{DS:}\quad \frac{P \lor Q,\qquad \neg P}{Q} \tag{23.1}$$

$$\textbf{Conj:}\quad \frac{P,\qquad Q}{P \land Q} \qquad\qquad \textbf{Simp:}\quad \frac{P \land Q}{P} \tag{24.1}$$

قاعدة الاستيعاب (Resolution) — قلب محرّكات SAT:

$$\frac{P \vee Q, \qquad \neg P \vee R}{Q \vee R} \tag{25.1}$$

الاستيعاب الوحدوي (Unit Resolution) — حالة خاصة بكثرة الاستخدام العملي:

$$\frac{P \vee Q, \qquad \neg P}{Q} \tag{26.1}$$

الاستيعاب بالتناقض (Refutation Completeness):

$$\Gamma \cup \{\neg \varphi\} \vdash_{\text{Res}} \square \iff \Gamma \models \varphi \tag{27.1}$$

نظرية الصحة والكمال (Soundness & Completeness):

$$\Gamma \vdash \varphi \iff \Gamma \models \varphi \tag{28.1}$$

2.6.1 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
$\frac{A}{B}$	إطار استدلال	من المقدّمات A نستنتج B	« rule inference »
$P \to Q$	اللزوم المادي	كاذب فقط إذا $P = 1$ و $Q = 0$	ليس سببية
$\vdash$	الاشتقاق التركيبي	يوجد برهان بالقواعد	« provability »
$\models$	اللزوم الدلالي	كل نموذج يُحقّق المقدّمات يُحقّق النتيجة	« entailment »
$\square$	الفقرة الفارغة	التناقض (empty clause)	تعني «غير قابل للإرضاء»
Γ	قاعدة المعرفة	مجموعة الصيغ/الحقائق	base knowledge
φ	الهدف	الصيغة المراد إثباتها	goal / query
$\vdash_{\text{Res}}$	اشتقاق بالاستيعاب	تقييد القواعد على (25.1)	—
$\neg\varphi$	نفي الهدف	يُضاف للتناقض في (27.1)	« refutation as negation »
clause في الـ $\vee$	فصل الحروف	الـ clause = فصل (OR) رموز	صيغة CNF
Literal	حرف	رمز أو نفيه (P أو $\neg P$)	وحدة بناء الـ clause

3.6.1 الشكل الهندسي

شكل (5.1): أعلى: وضع القضية (MP). أسفل: الاستيعاب يدمج فصلين يتضادّان في P فيُلغيانه.

4.6.1 البرهان

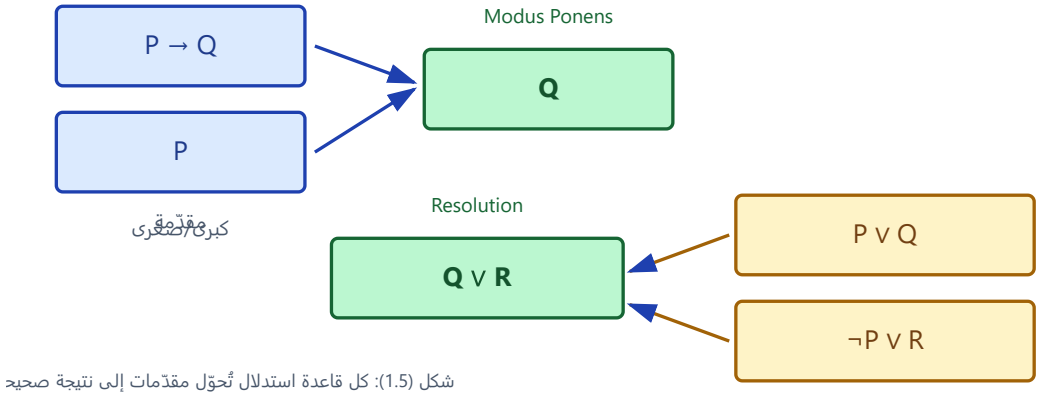
صحة (20.1) Ponens Modus بجدول الصدق:

P	Q	$P \to Q$	$P \wedge (P \to Q)$	النتيجة Q
0	0	1	0	—
0	1	1	0	—
1	0	0	0	—
1	**1**	1	**1**	✓ **1**

في الصف الوحيد الذي تصدق فيه المقدّمات معاً ($P = 1, P \to Q = 1$) تكون $Q = 1$ $\Longrightarrow$ القاعدة صحيحة.

صحة (25.1) الاستيعاب: نُثبت أن $(P \vee Q) \wedge (\neg P \vee R) \models (Q \vee R)$. نفترض نموذجاً يُحقّق المقدّمتين ولا يُحقّق النتيجة، أي $Q = 0$ و $R = 0$:

(Resolution) وقاعدة الاستيعاب (MP) قواعد الاستدلال: وضع القضية



شكل (1.5): كل قاعدة استدلال تُحوّل مقدّمات إلى نتيجة صحيح

شكل ٥.١: *
قواعد الاستدلال

$$(P \vee \underbrace{Q}_{0}) \wedge (\neg P \vee \underbrace{R}_{0}) \;=\; P \wedge \neg P \;=\; \bot$$

تناقض $\Rightarrow$ لا يوجد نموذج مضاد $\Rightarrow$ القاعدة صحيحة. ■

ملاحظة على الكمال:

(28.1) جهة «الصحة» ($\Rightarrow$) بسيطة بالاستقراء على طول البرهان؛ جهة «الكمال» ($\Leftarrow$) أعمق (نظرية كمال غودل للمنطق القضيوي 1929، وصيغة الاستيعاب عند Robinson 1965) وتحتاج بناء نموذج من مجموعة متسقة قصوى — تُناقَش في فهرس المراجع.

5.6.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-5.1): نظام خبير طبي — التهاب السحايا

المعطيات: قاعدة المعرفة Γ:

١. $Fever \wedge NeckStiff \rightarrow Meningitis$

٢. $Meningitis \rightarrow Urgent$، حقائق: $Fever = 1$، $NeckStiff = 1$. المطلوب: هل الحالة عاجلة؟

الحل: الخطوة 1: من الحقائق و (Conj-24.1): $Fever \wedge NeckStiff = 1$. الخطوة 2: بـ MP (20.1) مع القاعدة 1: $Meningitis = 1$. الخطوة 3: بـ MP مع القاعدة 2 و $Meningitis = 1$: $Urgent = 1$. الخطوة 4: سلسلة الاشتقاق: $\Gamma \vdash Urgent$.
النتيجة: نعم، عاجلة. الربط بالذكاء الاصطناعي: هذه هي بنية النظم الخبيرة الكلاسيكية ؛(MYCIN) وفي الأنظمة الحديثة تُترجم القواعد إلى قيود ناعمة في نموذج عصبي-رمزي.

مثال (1.5-2): روبوت خدمة في مستشفى

المعطيات: 1. $BatteryLow \rightarrow ReturnToDock$؛ 2. $ReturnToDock \rightarrow \neg Deliver$؛ 3. $TaskAssigned \rightarrow Deliver$. الحقائق: $BatteryLow = 1$، $TaskAssigned = 1$. المطلوب: هل هناك تناقض في الأهداف؟

الحل: الخطوة 1: بـ MP مع 1: $ReturnToDock = 1$. الخطوة 2: بـ MP مع 2: $\neg Deliver = 1$ أي $Deliver = 0$. الخطوة 3: بـ MP مع 3 و $TaskAssigned = 1$: $Deliver = 1$. الخطوة 4: $Deliver \wedge \neg Deliver = \bot$ $\Longrightarrow$ تناقض.

النتيجة: نعم — يلزم منطق إعادة التخطيط أو استرخاء القيود. الربط بالذكاء الاصطناعي: كشف التناقض هو وظيفة مُخطِّط المهام؛ الأنظمة الحديثة تستخدم SAT/SMT لحلّه قبل التنفيذ (بدل الفشل أثناء الحركة).

مثال (1.5-3): تشخيص عطل في خط إنتاج

المعطيات: 1. $TempHigh \vee PressHigh$؛ 2. $PressHigh \rightarrow ValveFault$؛ 3. $\neg ValveFault$. المطلوب: استنتج العطل.

الحل: الخطوة 1: من 2 و 3 بـ MT (1.21): $\neg PressHigh$. الخطوة 2: من 1 و $\neg PressHigh$ بـ DS (1.23): $TempHigh$.

النتيجة: العطل ارتفاع الحرارة. الربط بالذكاء الاصطناعي: هذا «الاستدلال بالاستبعاد» هو نفسه ما تفعله أشجار القرار عند تتبّع مسار تصنيف، لكن بصيغة رمزية قابلة للتفسير والمراجعة.

مثال (1.5-4): قواعد أعمال في نظام توصية

المعطيات: 1. $NewUser \rightarrow ShowPopular$؛ 2. $ShowPopular \rightarrow \neg ShowNiche$؛ 3. $Premium \wedge \neg NewUser \rightarrow ShowNiche$. مستخدم: $Premium = 1$، $NewUser = 1$. المطلوب: ماذا يُعرض؟

الحل: الخطوة 1: بـ MP مع 1 و $NewUser = 1$: $ShowPopular = 1$. الخطوة 2: بـ MP مع 2: $\neg ShowNiche$. الخطوة 3: شرط القاعدة 3 يحتاج $\neg NewUser$ وهو 0 $\Longrightarrow$ لا تُطبَّق.

النتيجة: يُعرض «الشائع» فقط. الربط بالذكاء الاصطناعي: طبقات القواعد فوق نموذج التوصية (business rules layer) ضرورية للامتثال، ويجب فحص تناقضها آلياً قبل النشر.

مثال (1.5-5): التحقق من صحة برنامج (منطق هور)

المعطيات: ثلاثية هور $\{P\}$ code $\{Q\}$، لدينا:

١. $\{x > 0\}$ x+1 =: y $\{y > 1\}$؛ 2. $\{y > 1\}$ y*2 =: z $\{z > 2\}$. المطلوب: إثبات $\{x > 2\}$ z:=y*2 y:=x+1; $\{z > 0\}$.

الحل: الخطوة 1: بـ HS (22.1) نربط النتيجتين: من $\{x > 0\}$ نصل إلى $\{y > 1\}$ ثم إلى $\{z > 2\}$. الخطوة 2: قاعدة التركيب (Composition) في منطق هور هي بالضبط HS. الخطوة 3: إذن الثلاثية المركّبة صحيحة.

النتيجة: البرهان مقبول. الربط بالذكاء الاصطناعي: أدوات التحقق من عتاد/برمجيات الذكاء الاصطناعي (مثل التحقق من صحة مُجمّعات النماذج) تعتمد هذه السلاسل الاستدلالية.

مثال (1.5-6): استدلال في Prolog

المعطيات: قاعدة المعرفة: `` parent(ahmad, sara). parent(sara, omar). grandparent(X,Z) :- parent(X,Y), parent(Y,Z)`` المطلوب:* هل grandparent(ahmad, omar)؟

الحل: الخطوة 1: القاعدة بلغة الاستيعاب: $\neg parent(X,Y) \vee \neg parent(Y,Z) \vee grandparent(X,Z)$.

الخطوة 2: الوحدة $\neg grandparent(ahmad, omar)$ تُضاف للتناقض (27.1). الخطوة 3: بالاستيعاب مع الحقيقة $\neg parent(sara, Z) \vee grandparent(ahmad, Z) \Longrightarrow parent(ahmad, sara)$. الخطوة 4: بالاستيعاب مع $grandparent(ahmad, omar) \Longrightarrow parent(sara, omar)$ تعارض مع الوحدة المنفية $\Longrightarrow \square$.

النتيجة: نعم، أحمد جدّ عمر. الربط بالذكاء الاصطناعي: محرّك Prolog هو مقوّض استيعابي (SLD-resolution)؛ وفهمه شرط لفهم محرّكات الاستدلال الحديثة على الرسوم المعرفية.

مثال (1.5-7): ربط تنبيهات أمنية (SIEM) (Correlation)

المعطيات: 1. $FailedLogin \wedge Repeated \rightarrow BruteForce$، 2. $BruteForce \vee Exfiltration \rightarrow HighSeverity$، 3. $\neg HighSeverity$ (السياسة تمنع التصعيد الآن). المطلوب: ماذا يُستنتج؟

الحل: الخطوة 1: بـ MT (21.1) على 2 مع $\neg HighSeverity$: $\neg(BruteForce \vee Exfiltration)$.

الخطوة 2: بدي مورغان (2.1): $\neg BruteForce \wedge \neg Exfiltration$. الخطوة 3: بـ Simp: $\neg BruteForce$.

الخطوة 4: بـ MT على 1: $\neg(FailedLogin \wedge Repeated)$ $\Longrightarrow$ بدي مورغان: $\neg FailedLogin \vee \neg Repeated$.

النتيجة: ليس هناك هجوم قوي؛ والتنبيهات فردية عابرة. الربط بالذكاء الاصطناعي: «الاستدلال العكسي» (backward chaining) من السياسة إلى التنبيهات يقلّل الإيجابيات الكاذبة بنسبة كبيرة مقابل الاستدلال الأمامي الأعمى.

مثال (1.5-8): استدلال على رسم معرفي (Knowledge Graph)

المعطيات: 1. $LocatedIn(X,Y) \wedge CapitalOf(Y,Z) \rightarrow LocatedIn(X,Z)$ (انتقالية)؛ الحقائق: $LocatedIn(Cairo_Tower,\ Egypt)$، $CapitalOf(Egypt,\ Cairo)$... (لنصحّح: $Egypt \rightarrow Cairo$ علاقة hasCapital). المطلوب: استنتاج جديد قابل للاشتقاق.

الحل: الخطوة 1: نُطبّق MP على القاعدة مع الحقائق: $\wedge\ LocatedIn(Cairo_Tower,\ Egypt)$ $hasCapital(Egypt, Cairo)$. الخطوة 2: إذا كانت القاعدة: $LocatedIn(X,Y) \wedge hasCapital(Y,Z) \rightarrow NearCapital(Cairo_Tower,\ Cairo) \Longrightarrow NearCapital(X,Z)$. الخطوة 3: تُضاف الحقيقة الجديدة للرسم (materialization).

النتيجة: حقيقة جديدة مُشتقّة. الربط بالذكاء الاصطناعي: «إتمام الرسم المعرفي» (KG completion) يمكن أن يكون رمزياً (بالقواعد) أو تعلّمياً (تضمينات مثل TransE)؛ والنُهج الهجينة هي الأفضل حالياً.

مثال (1.5-9): نظام مرور ذكي

المعطيات: 1. $ExtendGreen \rightarrow \neg Congestion \wedge \neg Emergency$؛ 2. $Emergency \rightarrow Accident$؛ 3. $\neg ExtendGreen$. الحقائق: $Congestion = 1$، $Accident = 1$. المطلوب: ماذا يفعل النظام؟

الحل: الخطوة 1: بـ MP مع 3: $Emergency = 1$. الخطوة 2: بـ MP مع 2: $\neg ExtendGreen$. الخطوة 3: القاعدة 1 غير مُطبّقة (شرطها $\neg Emergency$ كاذب).

النتيجة: لا تمديد للأخضر؛ أولوية للطوارئ. الربط بالذكاء الاصطناعي: القواعد ذات الأولويات تُدار بـ «منطق التفضيل» (preference logic)؛ وعند تعارضها يلزم تحكّم (arbitration) صريح لا MP بسيط.

مثال (1.5-10): موافقة ائتمانية بنكية

المعطيات: 1. $ScoreHigh \rightarrow Approve$؛ 2. $DebtHigh \rightarrow \neg Approve$؛ 3. $ScoreHigh \vee DebtHigh$ (حصر). مقدم: $ScoreHigh = 1$. المطلوب: القرار وهل القواعد متسقة؟

الحل: الخطوة 1: بـ MP مع 1: $Approve = 1$. الخطوة 2: من 3 و $ScoreHigh$ بـ DS نستنتج... بل: $ScoreHigh \vee DebtHigh$ صادق أصلاً، لا نستنتج $\neg DebtHigh$ إلّا بالحصر. الخطوة 3: **فحص التساق:** النموذج $ScoreHigh = 1,\ DebtHigh = 1$ يُحقّق 3 ويُنتج من 1 $Approve$ ومن 2 $\neg Approve$ $\Longrightarrow$ **غير متسقة.**

النتيجة: قاعدة المعرفة متناقضة $\Longrightarrow$ يلزم قاعدة أولوية (مثلاً: $DebtHigh$ يعلو). الربط بالذكاء الاصطناعي: «اكتشاف التناقض في قواعد الأعمال» خطوة إلزامية قبل تشغيل أي نظام قرار آلي؛ ويُنفَّذ باستدعاء SAT solver.

مثال (1.5-11): استدلال سببي (Causal Inference)

المعطيات: 1. $Smoking \rightarrow Tar$؛ 2. $Tar \rightarrow Cancer$؛ 3. ملاحظة: $\neg Cancer$ لدى مريض. المطلوب: ماذا نستنتج عن التدخين؟ ولماذا هذا ليس دليلاً سببياً كافياً؟

الحل: الخطوة 1: بـ HS (1.22) من 1 و 2: $Cancer \rightarrow Smoking$. الخطوة 2: بـ MT (1.21) مع $\neg Cancer$: $\neg Smoking$. الخطوة 3: **تحذير:** هذا الاستنتاج صحيح **دلالياً** فقط إذا كانت القواعد صادقة حتمياً؛ في الواقع العلاقات احتمالية فتُستبدل بـ $\mathbb{P}(Cancer \mid do(Smoking))$ (حساب تفاضلي سببي).

النتيجة: منطقياً $\neg Smoking$؛ سببياً: استنتاج ضعيف. الربط بالذكاء الاصطناعي: **درس جوهري:** $P \rightarrow Q$ لزومٌ مادي لا سببية؛ الارتباط $\neq$ السببية، والاستدلال السببي يحتاج تدخّلات $do(\cdot)$ لا ملاحظات.

مثال (1.5-12): تحويل قاعدة إلى قيد في خسارة عصبية-رمزية

المعطيات: قاعدة: $HasWings \wedge \neg CanFly \rightarrow Penguin$. نريد فرضها في تدريب شبكة. المطلوب: صياغة القيد ودالة الخسارة.

الحل: الخطوة 1: نحوّل القاعدة إلى CNF: $\neg HasWings \vee CanFly \vee Penguin$. الخطوة 2: درجة الإرضاء الضبابية بمنطق لوكاسيفيتش: $\mu = \min\{1,\ (1-\mu_W) + \mu_F + \mu_P\}$. الخطوة 3: الخسارة $\mathcal{L}_{rule} = \lambda\,(1-\mu)$؛ نجمعها مع خسارة التصنيف. الخطوة 4: التدرّج يجعل الشبكة تُرضي القاعدة تدريجياً.

النتيجة: قيدٌ قابل للاشتقاق. الربط بالذكاء الاصطناعي: هذا هو جوهر الذكاء العصبي-الرمزي (Neuro-Symbolic AI): المنطق يصبح منتظِماً (regularizer) لا مرشّحاً بعدياً.

مثال (1.5-13): تحليل السبب الجذري في خدمة سحابية

المعطيات: 1. $DiskFull \vee MemLeak \rightarrow Slow$؛ 2. $Slow \rightarrow Timeouts$؛ 3. $Timeouts \rightarrow \neg SLO$؛ 4. $\neg DiskFull$ (مؤكَّد بالقياس). الحقائق: $\neg SLO = 1$ (انتهاك اتفاقية المستوى). المطلوب: السبب الجذري.

الحل: الخطوة 1: لا يمكن عكس MT 3 يعطي $\neg SLO \Rightarrow$ لا شيء؛ MT يعمل من نفي التالي: $\neg Timeouts$... غير متاح). نستخدم الاستيعاب: الخطوة 2: الصيغ كـ clauses: $(\neg DiskFull \vee Slow)$... نعيد صياغة 1: $DiskFull \vee MemLeak \vee Slow$ لا، بل 1 هي $(DiskFull \vee MemLeak) \rightarrow Slow \equiv (\neg DiskFull \vee Slow) \wedge (\neg MemLeak \vee Slow)$. الخطوة 3: من $\neg DiskFull$ و $(\neg DiskFull \vee Slow)$ لا نستنتج $Slow$ (الوحدة موجبة). نحتاج ملاحظة $Slow$ لاستنتاج $MemLeak$ من $(\neg MemLeak \vee Slow)$؟ بـ MT على $(MemLeak \rightarrow Slow) \equiv (\neg MemLeak \vee Slow)$ نحتاج $\neg Slow$. الخطوة 4: بالتحليل: القرائن المتاحة لا تكفي لتحديد السبب $\Longrightarrow$ **الاستنتاج غير حاسم.**

النتيجة: المعطيات غير كافية، يلزم قياس إضافي. الربط بالذكاء الاصطناعي: **درس منهجي مهم:** غياب الاستنتاج مشكلة بحدّ ذاته، تُعالَج بـ «المنطق غير المتأكد» (abduction) حيث نبحث عن أصغر تفسير (minimal explanation) — وهو ما تفعله أنظمة AIOps الحديثة.

مثال (1.5-14): امتثال تنظيمي (Regulatory Compliance)

المعطيات: 1. $EUResident \wedge PersonalData \rightarrow GDPRApplies$؛ 2. $GDPRApplies \rightarrow ConsentRequired$؛ 3. $ConsentRequired \wedge \neg ConsentLogged \rightarrow Violation$. حالة: $EUResident = 1$، $PersonalData = 1$، $ConsentLogged = 0$. المطلوب: هل هناك انتهاك؟

الحل: الخطوة 1: بـ Conj ثم MP مع 1: $GDPRApplies = 1$. الخطوة 2: بـ MP مع 2: $ConsentRequired = 1$. الخطوة 3: بـ Conj مع $\neg ConsentLogged$: الشرط كامل $\Longrightarrow$ بـ MP مع 3: $Violation = 1$.

النتيجة: نعم، انتهاك مؤكَّد. الربط بالذكاء الاصطناعي: «الذكاء الاصطناعي القابل للتفسير والتدقيق» (auditable AI) يحتاج سلاسل استدلال من هذا النوع: كل قرار يجب أن يُرفق بمسار اشتقاق قابل للمراجعة القانونية.

مثال (15-5.1): إثبات عدم الإرضاء بمحرّك (Resolution SAT (Refutation

المعطيات: الصيغة $\Gamma = \{(A \vee B),\ (\neg A \vee C),\ (\neg B),\ (\neg C)\}$. المطلوب: أثبت بالاستيعاب أن Γ غير قابلة للإرضاء.

الحل: الخطوة 1: من $(A \vee B)$ و $(\neg B)$ بالاستيعاب الوحدوي (26.1): A. الخطوة 2: من $(\neg A \vee C)$ و A: C. الخطوة 3: من C و $(\neg C)$: $\square$ (فقرة فارغة). الخطوة 4: الوصول إلى $\square$ يعني التناقض $\Gamma \models \bot \implies$.

النتيجة: الصيغة غير قابلة للإرضاء. (UNSAT) الربط بالذكاء الاصطناعي: محرّكات SAT الحديثة (CDCL) تُعمّم هذه الخطوة إلى ملايين الفقرات، وتُستخدم في التحقق من الشبكات العصبية (مثل إثبات متانة adversarial robustness) وفي الجدولة والتخطيط.

6.6.1 أخطاء شائعة

الخطأ	الصواب
من $P \to Q$ و Q استنتاج P	هذه مغالطة «إثبات التالي» (affirming the consequent)
من $P \to Q$ و $\neg P$ استنتاج $\neg Q$	مغالطة «نفي السابق» (denying the antecedent)
اعتبار $P \to Q$ سببية	لزوم مادي فقط؛ السببية تحتاج $do(\cdot)$
الخلط بين $\vdash$ و $\models$	الأول اشتقاق آلي، الثاني صحة دلالية؛ يجمعهما (28.1)
ظنّ أن الاستيعاب يحتاج حرفين متضادّين فقط	نعم يحتاجهما، والنتيجة فصل الباقي

صُمّمت التمارين على ثلاثة مستويات: (أ) تطبيق مباشر، (ب) تركيب، (ج) تحدٍّ بحثي-تطبيقي. الإجابات المختصرة في نهاية القسم.

المستوى (أ) — تطبيق مباشر

١. بسّط: $\neg(\neg P \vee Q)$ بصيغة لا تحتوي نفياً مزدوجاً.

٢. بسّط: $\neg(A \wedge (B \vee C))$ إلى صيغة على OR/AND مع نفي على الرموز فقط.

٣. في فصلٍ من 60 طالباً: 35 يدرسون الرياضيات و 30 الفيزياء و 12 الاثنتين. كم لا يدرس أيّاً منهما؟

٤. احسب $|A \cup B \cup C|$ إن كانت الأحجام 100 و 80 و 60، والأزواج 30 و 20 و 15، والثلاثي 8.

٥. أثبت بالاستقراء: $\sum_{i=1}^{n} i = \frac{n(n+1)}{2}$.

٦. أثبت بالاستقراء: $\sum_{i=1}^{n} 2^i = 2^{n+1} - 2$.

٧. كم عدداً من الأشخاص يلزم لضمان أن ثلاثة منهم وُلدوا في الشهر ذاته؟

٨. 25 كتاباً على 6 رفوف: أثبت وجود رفٍّ بـ ≥ 5 كتب.

٩. من $(P \to Q)$ و $(Q \to R)$ و P، استنتج R مبيناً القاعدة المستخدمة في كل خطوة.

١٠. حوّل القاعدة $(A \wedge B) \to C$ إلى CNF.

المستوى (ب) — تركيب

١. في مجموعة بيانات 50,000 صورة: معيارات الجودة ثلاثة بأحجام 45,000 و 40,000 و 42,000، والأزواج 36,000 و 38,000 و 34,000، والثلاثي 31,000. احسب الصور الصالحة.

٢. أثبت بالاستقراء القوي أن كل عدد صحيح $n \geq 2$ يكتب كجداء أعداد أولية.

٣. استخدم مبدأ الحمام لإثبات أن أي خوارزمية فرز بالمقارنة... (تلميح: اربط بعدد التبديلات $n!$ وعدد أشجار القرار الممكنة).

٤. أثبت أن $\neg(P \oplus Q) \equiv (P \leftrightarrow Q)$.

٥. أثبت صحة قاعدة الاستيعاب (25.1) بجدول صدق كامل.

٦. أثبت أن $\big((P \to Q) \wedge (Q \to R)\big) \to (P \to R)$ قضية دائمة الصدق (tautology).

٧. أثبت بالاستقراء أن عدد حواف الرسم البياني الكامل K_n هو $\frac{n(n-1)}{2}$.

٨. في شبكة من 500 عقدة و 1,000 وصلة: أثبت وجود عقدة درجتها ≥ 4 بالاستقراء... بل بمبدأ الحمام على مجموع الدرجات.

٩. أثبت بالاستقراء أن $n^3 + 2n$ يقبل القسمة على 3 لكل $n \in \mathbb{N}$.

١٠. استخدم الشمول والاستبعال لإثبات صيغة عدد التبديلات التي لا تُثبّت أي عنصر (derangements) $D_n = n! \sum_{k=0}^{n} \frac{(-1)^k}{k!}$.

المستوى (ج) — تحدٍّ

١. بيّن أن الاستقراء الضعيف (12.1) والقوي (13.1) متكافئان منطقياً.

٢. أثبت بمبدأ حسن الترتيب أن كل كسر $\frac{a}{b}$ يمكن تبسيطه إلى أبسط صورة.

٣. صِغ «مبدأ الحمام الاحتمالي»: إن كان $n > m$ فاحتمال خلوّ صندوق مختار عشوائياً من التصادم $\leq \ldots$ وبيّن حدّه.

٤. في نموذج لغة بقاموس حجمه $|V| = 50{,}000$ ومساحة تضمين $d = 128$: استخدم مبدأ الحمام لمناقشة إمكانية تضمين «لا تصادمي» للكلمات.

٥. أثبت أن قاعدة الاستيعاب مع وحدات فقط تكفي لإثبات أي نتيجة من قاعدة معرفة على شكل قواعد Horn (وهو أساس Prolog).

٦. بيّن أن دي مورغان يعمّم على المنطق الضبابي بـ t-norms: متى يصحّ ومتى يفشل؟

٧. استخدم مبدأ الحمام لإثبات أن لا يوجد ضغط بدون فقد يقلّص **كل** الملفات (بصيغة دقيقة).

٨. أثبت بالاستقراء البنيوي أن كل شجرة ثنائية بحث صحيحة تُنتج ترتيباً تصاعدياً عند المسح بالترتيب (in-order).

٩. في شبكة عصبية بـ L طبقة واتصالات متبقّية اختيارية: أثبت بالاستقراء أن عدد الشبكات الفرعية الممكنة 2^L، وناقش أثر ذلك على التعميم.

١٠. صُمّم قاعدة معرفة من 5 قواعد Horn لنظام كشف احتيال، ثم أثبت بالاستيعاب أن حالةً محدّدة تُصنَّف «احتيال».

إجابات مختصرة

#	الإجابة
1	$P \wedge \neg Q$
2	$(\neg A \vee \neg B) \wedge (\neg A \vee \neg C) \iff \neg A \vee (\neg B \wedge \neg C)$
3	$60 - (35 + 30 - 12) = 7$
4	$240 - 65 + 8 = 183$
5	الأساس $n=1$: ✓ 1؛ الخطوة: $\frac{k(k+1)}{2} + (k+1) = \frac{(k+1)(k+2)}{2}$
6	الأساس $n=1$: ✓ 2؛ الخطوة: $(2^{k+1} - 2) + 2^{k+1} = 2^{k+2} - 2$
7	$2 \times 12 + 1 = 25$ شخصاً
8	$\lceil 25/6 \rceil = 5$
9	HS ثم MP (مرتين)
10	$\neg A \vee \neg B \vee C$
11	$127{,}000 - 108{,}000 + 31{,}000 = 50{,}000$ (كلها صالحة)
12	إن كان n أولياً انتهى، وإلا $n = ab$ مع $a, b < n$ فبالفرض القوي كلٌّ منهما جداء أوليّات
13	$n!$ تبديلات تحتاج شجرة قرار بـ $\geq n!$ ورقة؛ ارتفاعها $\geq \log_2(n!) = \Omega(n \log n)$
14	جدول صدق: يتطابقان في الصفوف الأربعة
15	أربع صفوف؛ في كل صف تصدق المقدّمتان تصدق $Q \vee R$
16	الصيغة كاذبة فقط لو $P=1, Q=1, R=0$... تحقق: الصفوف الثمانية كلها 1
17	الأساس $n=1$: ✓ 0؛ الخطوة: K_{k+1} يضيف k حواف
18	مجموع الدرجات $= 2 \times 1000 = 2000$؛ المتوسط $= 4 \implies$ عقدة بدرجة ≥ 4
19	الأساس $n=0$: ✓ 0؛ الخطوة: $(k+1)^3 + 2(k+1) - (k^3 + 2k) = 3k^2 + 3k + 3$ يقبل القسمة على 3
20	الشمول والاستبعال على أحداث «العنصر i مثبّت»
21	بتعريف $Q(n) = \forall j \leq n : P(j)$، فالاستقراء الضعيف على Q يعطي القوي والعكس بديهي
22	اختر أصغر بسط موجب بين الكسور المكافئة
23	$\mathbb{P}$(تصادم) $\geq 1 - \frac{m!}{m^n}\binom{m}{n} n!$ (صيغة عيد الميلاد المعمّمة)
24	التضمين في $\mathbb{R}^{128}$ متصل؛ لا تصادم ممكن نظرياً لكن تمييزها يعتمد على بعد المسافات
25	كل قاعدة Horn = clause بـliterals موجبة $\leq 1 \implies$ الاستيعاب يحفظ هذه الخاصية
26	يصحّ مع t-norms مزدوجة من t-conorm متوافقة (مثل min/max، وجداء/مجموع احتمالي)
27	انظر مثال (3-4.1) مع تعميم على أطوال متفاوتة
28	ورقة ✓؛ عقدة: اليسار أصغر واليمين أكبر بالفرض $\implies$ المسح مرتّب
29	كما في مثال (12-3.1)
30	مفتوح — صمّمه وأرسله للمراجعة

القانون	الصيغة المحورية	متى تستخدمه
دي مورغان	$\neg(P \wedge Q) \equiv \neg P \vee \neg Q$	تبسيط الشروط المنفية، CNF/DNF دوائر منطقية
الشمول والاستبعاد	$\lvert\cup A_i\rvert = \sum \lvert A_i\rvert - \sum \lvert A_i \cap A_j\rvert + \cdots$	العدّ والاحتمال مع تداخلات
الاستقراء الرياضي	$P(n_0) \wedge [P(k) \Rightarrow P(k+1)] \Rightarrow \forall n\, P(n)$	إثبات صحة/تعقيد خوارزميات متكرّرة
مبدأ الحمام	$\exists j : \lvert A_j\rvert \geq \lceil n/m \rceil$	حدود دنيا مضمونة وإثبات الاستحالة
قواعد الاستدلال والاستيعاب	$\dfrac{P \vee Q,\ \neg P \vee R}{Q \vee R}$؛ $\Gamma \vdash \varphi \iff \Gamma \models \varphi$	محرّكات الاستدلال و SAT

الخيط الناظم: كل هذه القوانين هي طرقٌ لمعالجة **البنى المنفصلة** — وهي اللغة التي تُكتب بها الخوارزميات والمعرفة. في الفصل القادم ننتقل إلى البنى **المتصلة**: الفضاءات المتجهة، حيث تعيش بيانات الذكاء الاصطناعي فعلياً.

الرمز	المعنى	القسم
$\neg,\ \wedge,\ \vee,\ \oplus$	نفي، عطف، فصل شامل، فصل حصري	1.1
$\rightarrow,\ \leftrightarrow,\ \equiv$	لزوم، تكافؤ (رابط)، تكافؤ (علاقة)	1.1
$\top,\ \bot$	صدق دائم، كذب دائم	1.1
$\vdash,\ \models,\ \Gamma,\ \varphi$	اشتقاق، لزوم دلالي، قاعدة معرفة، هدف	6.1
$\Omega,\ \omega,\ \in,\ \subseteq$	فضاء العوالم، عالم، انتماء، مجموعة فرعية	1.1
$\cup,\ \cap,\ ^c,\ \setminus$	اتحاد، تقاطع، متمّم، طرح	2.1
$\lvert A\rvert,\ \mathbb{P}(\cdot)$	عدد العناصر، الاحتمال	3.1
$\forall,\ \exists,\ \forall x,\ \exists x$	كمّيات شاملة ووجودية	2.1
$\lceil\cdot\rceil,\ \lfloor\cdot\rfloor$	سقف، أرضية	5.1
$\mathbb{N},\ n_0,\ k,\ j$	الأعداد الطبيعية، الأساس، مرتبة الاستقراء	4.1
$\sum,\ \binom{n}{k}$	مجموع، توافيق	3.1
$\square$	الفقرة الفارغة (تناقض)	6.1
$O(\cdot),\ T(n)$	ترميز التعقيد، دالة التكلفة	4.1

١. **Norvig & Russell** — *Artificial Intelligence: A Modern Approach*, Ch. 7–9 (المنطق القضيوي والمحمول والاستدلال).

٢. **Rosen** — *Discrete Mathematics and Its Applications*, Ch. 1–2, 5 (المنطق، المجموعات، الاستقراء).

٣. **Robinson (1965)** — *A Machine-Oriented Logic Based on the Resolution Principle* — الورقة المؤسِّسة لقاعدة الاستيعاب.

٤. **Biere et al.** — *Handbook of Satisfiability* — محرّكات SAT الحديثة (CDCL).

٥. **Vapnik** — *Statistical Learning Theory* — للربط بين مبدأ الحمام والسعة/بُعد VC (يُفصَّل في الفصل 31).

الفصل القادم: الفضاءات المتجهة والاستقلال الخطي — حيث تصبح البيانات «نقاطاً» والخوارزميات «تحويلات».

الفصل ٢

الفضاءات المتجهة، الاستقلال الخطي، والهندسة الداخلية

الشعار: «البيانات في الذكاء الاصطناعي ليست جداول؛ إنها **نقاط في فضاء متجهي**. وكل خوارزمية هي حركةٌ هندسية في ذلك الفضاء: إسقاط، تدوير، أو تقريب.»

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. التحقق من أن بنيةً ما فضاءً متجهي، وتحديد **بعدها** وأسسها.

٢. تطبيق **لامّة التبادل (شتاينيتز)** لحساب أبعاد الفضاءات الجزئية واتحادها وتقاطعها.

٣. استخدام **متراجحة كوشي–شفارتس** لضبط حدود التشابه والتدرّجات وثوابت ليبشيتز.

٤. حساب **الإسقاط المتعامد** كأفضل تقريب، وفهمه بوصفه الانحدار الخطي والـ PCA وضغط النماذج.

٥. بناء أساس متعامد بـ **غرام–شميدت** واستخراج **تحليل QR**.

٦. استخدام **نظرية الرتبة والعدمية** لتشخيص انهيار الرتبة وتحديد المعلمات الفعّالة.

المتطلبات المسبقة

الفصل الأول (المنطق والمجموعات والبرهان). لا يُفترض معرفة مسبقة بالجبر الخطي.

خريطة الفصل

القسم	النظرية/القانون	عدد الأمثلة المحلولة
1.2	الفضاء المتجهي: البديهيات والنتائج الفورية	—
2.2	**لامّة التبادل لشتاينيتز وثبات البُعد**	15
3.2	**متراجحة كوشي–شفارتس ومتراجحة المثلث**	15
4.2	**نظرية الإسقاط المتعامد وأفضل تقريب**	15
5.2	**غرام–شميدت والتحليل QR**	15
6.2	**نظرية الرتبة والعدمية**	15
7.2	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

Steinitz · Dimension · Basis · Span · Independence Linear · Subspace · Field · Space Vector · Projection Orthogonal · Inequality Cauchy–Schwarz · Product Inner · Lemma Exchange / Image · Space Null / Kernel · Theorem Rank–Nullity · Decomposition QR · Gram–Schmidt Range

1.1.2 التعريف الرسمي

الفضاء المتجهي على حقل $\mathbb{F}$ (عملياً $\mathbb{R}$ أو $\mathbb{C}$) هو مجموعة V مزوّدة بعمليتين — الجمع $+ : V \times V \to V$ والضرب القياسي $\cdot : \mathbb{F} \times V \to V$ — تحقّق البديهيات الثماني:

$$\forall\, u, v, w \in V: \quad (u + v) + w \;=\; u + (v + w) \tag{A1}$$

$$\forall\, u, v \in V: \quad u + v \;=\; v + u \tag{A2}$$

$$\exists\, \mathbf{0} \in V:\ \forall v \in V: \quad v + \mathbf{0} \;=\; v \tag{A3}$$

$$\forall v \in V,\ \exists (-v) \in V: \quad v + (-v) \;=\; \mathbf{0} \tag{A4}$$

$$\forall\, \alpha, \beta \in \mathbb{F},\ \forall v \in V: \quad \alpha(\beta v) \;=\; (\alpha\beta) v \tag{A5}$$

$$\forall v \in V: \quad 1 \cdot v \;=\; v \tag{A6}$$

$$\forall \alpha \in \mathbb{F},\ \forall u, v \in V: \quad \alpha(u + v) \;=\; \alpha u + \alpha v \tag{A7}$$

$$\forall\, \alpha, \beta \in \mathbb{F},\ \forall v \in V: \quad (\alpha + \beta) v \;=\; \alpha v + \beta v \tag{A8}$$

2.1.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة تطبيقية
V	الفضاء المتجهي	مجموعة العناصر (متجهات) مع عمليتين	في ML: فضاء التمثيل/الميزات
$\mathbb{F}$	الحقل	$\mathbb{R}$ (حقيقي) أو $\mathbb{C}$ (مركّب)	$\mathbb{R}$ هو المعتاد
u, v, w	متجهات	عناصر V	عيّنة، تضمين، صورة
$\mathbf{0}$	المتجه الصفري	العنصر المحايد للجمع	تضمين «فارغ»
$-v$	المعاكس الجمعي	بحيث $v + (-v) = \mathbf{0}$	—
α, β	قياسات (scalars)	عناصر الحقل	معدّل تعلّم، وزن
$\mathbb{R}^n$	الفضاء الإقليدي n-البعد	المتجهات الحقيقية بطول n	متجه ميزات
$\mathbb{R}^{m \times n}$	فضاء المصفوفات	مصفوفات $m \times n$	أوزان طبقة
$\operatorname{span}(S)$	التوليد	أصغر فضاء جزئي يحتوي S	فضاء الحلول الممكنة
$U \le V$	فضاء جزئي	مغلقة على العمليتين U	فضاء كامن (latent)
$\dim V$	البُعد	عدد عناصر أي أساس	عدد الميزات/القنوات
$\oplus$	الجمع المباشر	$V = U \oplus W$ مع $U \cap W = \{0\}$	تحليل متعامد

3.1.2 نتائج فورية (تُثبت بخطوتين من البديهيات)

$$\alpha \cdot \mathbf{0} = \mathbf{0} \qquad (-1)\cdot v = -v; \qquad 0 \cdot v = \mathbf{0}; \qquad (-v) \text{ وحيد}; \qquad \mathbf{0} \text{ وحيد}; \tag{0.2}$$

الربط بالذكاء الاصطناعي: لا تُخزَّن الصورة في الذاكرة كـ «صورة» بل كمتجه في $\mathbb{R}^{784}$ (صورة 28×28). والكلمة تُخزَّن كمتجه في $\mathbb{R}^{300}$. وبما أن العمليات هي جمع وضرب قياسي فقط، فإن كل خوارزمية تعلّم هي **تركيب خطي ثم لاخطية** — هذه هي البنية الكاملة للشبكة العصبية.

4.1.2 الاستقلال الخطي والأساس

مجموعة $\{v_1, \dots, v_k\}$ **مستقلة خطياً** إذا:

$$\sum_{i=1}^{k} \alpha_i v_i = \mathbf{0} \quad \Longrightarrow \quad \alpha_1 = \alpha_2 = \cdots = \alpha_k = 0 \tag{1.2}$$

وهي **أساس** لـ V إذا كانت مستقلة و تولّد V:

$$\mathcal{B} = \{b_1, \dots, b_n\} : \quad \operatorname{span}(\mathcal{B}) = V \ \wedge \ \mathcal{B} \text{ مستقلة} \tag{2.2}$$

صاغها: إرنست شتاينيتز (1910). وهي النظرية التي تجعل كلمة «البُعد» ذات معنى: لا يمكن لفضاءٍ واحد أن يكون له بُعدان مختلفان.

1.2.2 الصياغة الرسمية

لامّة التبادل:

إذا كانت $\{v_1, \dots, v_m\}$ تولّد V، وكانت $\{w_1, \dots, w_k\}$ مستقلةً خطياً في V، فإن:

$$k \ \le \ m \tag{3.2}$$

ويمكن استبدال k من المتجهات v_i بالمتجهات w_j مع الحفاظ على التوليد.

نتيجة — ثبات البُعد:

$$\mathcal{B}_1,\ \mathcal{B}_2 \text{ أساسان لـ } V \implies |\mathcal{B}_1| = |\mathcal{B}_2| \ =: \ \dim V \tag{4.2}$$

نتيجة — صيغة الفضاءين الجزئيين:

$$\dim(U + W) \ = \ \dim U \ + \ \dim W \ - \ \dim(U \cap W) \tag{5.2}$$

$$U \cap W = \{\mathbf{0}\} \implies \dim(U \oplus W) \ = \ \dim U + \dim W \tag{6.2}$$

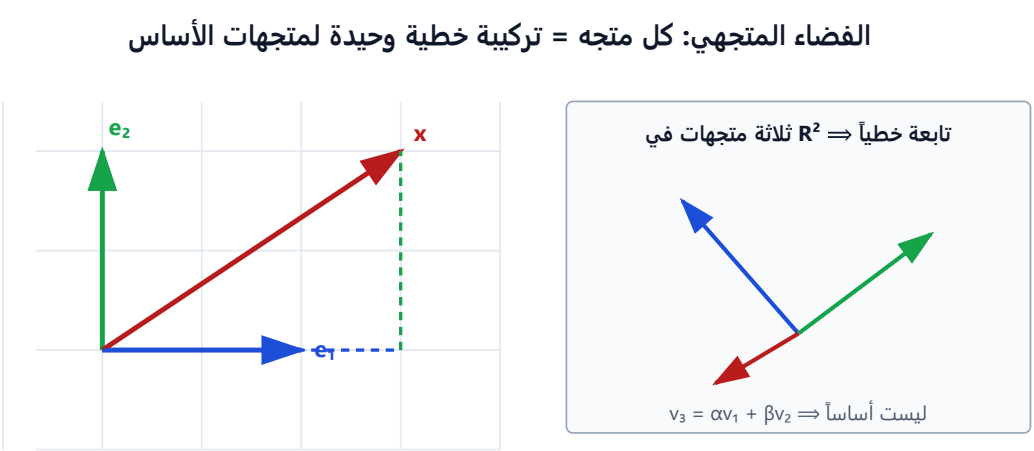
نتيجة — الحدود العملية:

$$\dim \operatorname{span}\{v_1, \dots, v_k\} \ \le \ k, \qquad \text{وفي } \mathbb{R}^n : \ \text{أي } n+1 \text{ متجه تابعة خطياً} \tag{7.2}$$

2.2.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
m	عدد المولّدات	حجم المجموعة التي تولّد V	حدّ أعلوي للبُعد
k	عدد المستقلّة	حجم المجموعة المستقلة	حدّ أدنوي للبُعد
$\lvert\mathcal{B}\rvert$	عدد عناصر الأساس	$\dim V$ =	—
$U + W$	مجموع الفضاءين	$\{u + w : u \in U,\ w \in W\}$	ليس necessarily مباشراً
$U \cap W$	التقاطع	ما يشتركان فيه	سبب الطرح في (5.2)
$\oplus$	الجمع المباشر	مجموع بتقاطع صفري	التباس: لا يُطرح شيء
rank	الرتبة	بُعد فضاء الأعمدة	= بُعد الصورة
span	التوليد	جميع التركيبات الخطية	—

3.2.2 الشكل الهندسي



شكل (2.1): الأساس = أصغر مجموعة تولّد الفضاء، وأكبر مجموعة مستقلة فيه؛ عددها = البُعد

شكل ١.٢: *
الفضاء المتجهي والأساس

شكل (1.2): يساراً: كل متجه x تركيبة خطية وحيدة من $\{e_1, e_2\}$. يميناً: ثلاثة متجهات في $\mathbb{R}^2 \implies$ تابعة بالضرورة (باللامّة 3.2 مع $k = 3 > m = 2$).

4.2.2 البرهان

لامّة التبادل:

نُثبت بالإحلال المتدرّج. بما أن $\{v_i\}$ تولّد V والمجموعة $\{w_j\}$ مستقلة، فإن $w_1 \neq \mathbf{0}$ (وإلا لكانت تابعة)، فـ $w_1 = \sum_i c_i v_i$ مع بعض $c_{i_1} \neq 0$. نحلّ المعادلة فنعوّض عن v_{i_1} بـ w_1 ومضاعفات الـ v الأخرى $\implies$ المجموعة الجديدة ما زالت تولّد V.

نكرّر للمتجه w_2: لو كان w_2 تركيبةً من v المتبقية فقط، لكان تركيبةً من $\{w_1\}$ المتبقية وv... بالتفصيل: في كل خطوة نستهلك مولّداً واحداً ونضيف متجهاً مستقلاً واحداً. لو نفدت المولّدات قبل استيعاب كل w_j (أي $k > m$)، لكان أحد الـ w المتبقية تركيبةً خطية لـ w المضافة سابقاً $\implies$ تناقض مع الاستقلال. إذن $k \leq m$. ■

ثبات البُعد (4.2): إذا كان $\mathcal{B}_1$ أساساً (مولّد) و $\mathcal{B}_2$ أساساً (مستقل)، فباللاّمة: $|\mathcal{B}_1| \leq |\mathcal{B}_2|$؛ وبتبادل الدورين: $|\mathcal{B}_2| \leq |\mathcal{B}_1| \implies$ التساوي.

5.2.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-1.2): بُعد فضاء ميزات جدول بيانات

المعطيات: جدول فيه 12 عموداً: 10 ميزات رقمية + عمود «المدينة» (8 مدن) مشفّر one-hot + عمود هدف. المطلوب: بُعد فضاء الميزات بعد الترميز.

الحل: الخطوة 1: 10 ميزات رقمية $\implies$ 10 أبعاد. الخطوة 2: one-hot لـ 8 مدن $\implies$ 8 أعمدة، لكن مجموعها $1 =$ $\implies$ التابع خطياً موجود $\implies$ الاستقلال يعطي $7 = 1 - 8$ أبعاد فعّالة (أو 8 في فضاء الميزات الخام). الخطوة 3: الإجمالي $18 = 8 + 10 =$ بعداً خاماً (أو 17 بعد إسقاط التبعية).

النتيجة: $18 =$ dim خاماً / 17 فعّالاً. الربط بالذكاء الاصطناعي: هذا هو مصدر **فخّ المتغيّر الوهمي** (dummy variable trap): التبعية الخطية تجعل مصفوفة $X^\top X$ غير قابلة للعكس $\implies$ الانحدار الخطي ينهار. الحل: إسقاط عمود واحد.

مثال (2-1.2): هل 300 بُعداً تكفي لتضمين الكلمات؟

المعطيات: قاموس $|V| = 100{,}000$ كلمة؛ تضمينات في $\mathbb{R}^{300}$. المطلوب: كم كلمة يمكن أن تكون مستقلة خطياً؟ وهل البعد كافٍ؟

الحل: الخطوة 1: في $\mathbb{R}^{300}$ أي 301 متجه تابعة خطياً (7.2). الخطوة 2: لكن عدد المتجهات **المستقلة** لا يحدّد التمييز العملي؛ المهم الزوايا: في $\mathbb{R}^d$ يمكن وضع $\approx e^{0.21d}$ متجهاً شبه متعامد (بزاوية $\geq 89°$). الخطوة 3: لـ $d = 300$: عدد ضخم $\gg 100{,}000 \implies$ كافٍ.

النتيجة: 300 بُعداً تكفي بوفرة لتمييز 100 ألف كلمة. الربط بالذكاء الاصطناعي: هذا هو التبرير الهندسي لنجاح word2vec/GloVe بأبعاد 100–300: ليس مطلوباً الاستقلال التام بل **التمييز الزاوي**، والفضاءات عالية البعد «متسعة» بشكل مضاد للحدس.

مثال (3-1.2): one-hot والبعد الفعّال

المعطيات: تصنيف من 5 أصناف بـ one-hot في $\mathbb{R}^5$، متوسط المجموع $1 =$. المطلوب: بُعد الفضاء الجزئي (affine) الذي تعيش فيه هذه المتجهات.

الحل: الخطوة 1: القيد $\sum_i x_i = 1$ هو معادلة خطية واحدة غير صفرية $\implies$ يخفض البعد بمقدار 1. الخطوة 2: الفضاء الجزئي الخطي المولّد من الفروق له بُعد $4 = 1 - 5$. الخطوة 3: المتجهات الخمس (one-hot) مستقلة **تآلفياً** لا خطياً: $\sum_{i=1}^{5} e_i \cdot 1 \ldots$ بل المتجهات نفسها مستقلة خطياً (5 متجهات في $\mathbb{R}^5$ تشكّل أساساً)، لكن **المدى** يقع في مستوٍ تآلفي بأبعاد 4.

النتيجة: البعد التآلفي 4، والبعد الخطي 5. الربط بالذكاء الاصطناعي: التمييز بين «بعد خطي» و«بعد تآلفي» يظهر في هندسة **logits** الشبكة: زيادة ثابتة لكل logits لا تغيّر softmax $\Longrightarrow$ الفضاء الفعّال أبعاده $C-1$.

مثال (2.1-4): اختيار عدد المركبات في PCA

المعطيات: بيانات في $\mathbb{R}^{50}$، نريد فضاءً جزئياً U يحفظ 95% من التباين. المطلوب: العلاقة بين $\dim U$ والتباين المفقود.

الحل: الخطوة 1: المتجهات k الأولى components Principal تولّد فضاءً جزئياً U بـ $\dim U = k$. الخطوة 2: الباقي في $U^{\perp}$ ببعد $50 - k$. الخطوة 3: التباين المفقود = مجموع القيم الذاتية على $U^{\perp}$. الخطوة 4: نختار أصغر k يحقّق $\sum_{i>k}\lambda_i / \sum_i \lambda_i \le 0.05$.

النتيجة: k = أول موضع يتجاوز فيه التباين التراكمي 95%. الربط بالذكاء الاصطناعي: اختيار k هو تحديد **بُعد الفضاء الكامن الفعّال**، وهو ما يُسمّى «intrinsic dimension» لمتعدّد البيانات (manfiold).

مثال (2.1-5): عدد الطبقات مقابل سعة التمثيل

المعطيات: شبكة بـ L طبقة مخفية عرضها h، التفعيلات في كل طبقة عناصر من $\mathbb{R}^h$. المطلوب: كم «منطقة خطية» يمكن أن تخلقها الشبكة في المدخل $\mathbb{R}^d$؟

الحل: الخطوة 1: كل خليةReLU تقسم الفضاء بنصف مستوٍ $\Longrightarrow$ الطبقة الأولى تخلق h نصف-مستوٍ. الخطوة 2: عدد المناطق الخطية لترتيب h مستوٍ في $\mathbb{R}^d$ هو $\sum_{i=0}^{d}\binom{h}{i} = O(h^d)$. الخطوة 3: مع L طبقة يتضاعف العدد أُسّياً مع L: $O\big((h^d)^L\big)$ في أسوأ تحليل.

النتيجة: السعة تنمو أُسّياً مع العمق. الربط بالذكاء الاصطناعي: هذا هو التفسير الحديث لتفوّق العمق على العرض: **العمق يضاعف السعة التركيبية** لا مجرد عدد المعلمات.

مثال (2.1-6): LoRA وفضاء التحديث منخفض الرتبة

المعطيات: وزن طبقة $W_0 \in \mathbb{R}^{m\times n}$، التحديث $\Delta W = BA$ مع $B \in \mathbb{R}^{m\times r}$، $A \in \mathbb{R}^{r\times n}$، $r \ll \min(m,n)$. المطلوب: بُعد فضاء التحديثات الممكنة.

الحل: الخطوة 1: ΔW يقع في فضاء المصفوفات ذات الرتبة $\le r$. الخطوة 2: بُعد فضاء المصفوفات $m \times n$ ذات الرتبة $\le r$ هو $r(m+n) - r^2$. الخطوة 3: عند $m = n = 4096$ و $r = 8$: $8(8192) - 64 = 65{,}472$ من أصل $16{,}777{,}216$ معلمة (0.39%).

النتيجة: يُدرَّب أقل من 0.4% من المعلمات. الربط بالذكاء الاصطناعي: الفرضية الضمنية: تحديثات الضبط الدقيق تعيش في **فضاء جزئي منخفض البعد** — وهذا تطبيق مباشر لمفهوم البُعد الجوهري.

مثال (2.1-7): حين يكون عدد العيّنات أقل من البعد

المعطيات: 40 عيّنة في $\mathbb{R}^{200}$ (مثل بيانات جينومية). المطلوب: هل يمكن أن تكون مصفوفة البيانات $X \in \mathbb{R}^{40\times 200}$ ذات رتبة كاملة؟

الحل: الخطوة 1: رتبة المصفوفة $\leq \min(40, 200) = 40$. الخطوة 2: بـ (7.2): صفوف X (العيّنات) 40 متجهاً في $\mathbb{R}^{200}$ $\Longrightarrow$ مستقلة ممكن، لكن الأعمدة 200 متجهاً في $\mathbb{R}^{40}$ $\Longrightarrow$ **تابعة حتماً**. الخطوة 3: إذن توجد تركيبات خطية غير تافهة بين الميزات $\Longrightarrow$ $X^\top X$ منفردة.

النتيجة: النظام غير محدّد $\Longrightarrow$ يلزم تنظيم (Ridge) أو تقليل أبعاد. الربط بالذكاء الاصطناعي: هذه هي الحالة $p \gg n$ الشائعة في الطب الحيوي، وتفسّر لماذا ينهار الانحدار squares least ordinary ويجب استخدام Lasso/Ridge.

مثال (2.1-8): بُعد فضاء القنوات في CNN

المعطيات: طبقة التفافية مخرجاتها خريطة ميزات $64 \times 56 \times 56$. المطلوب: بُعد فضاء التمثيل عند كل موقع مكاني، والبعد الكلي.

الحل: الخطوة 1: عند كل موقع: متجه في $\mathbb{R}^{64} \Longrightarrow \dim = 64$. الخطوة 2: البعد الكلي لخريطة الميزات $= 56 \times 56 \times 64 = 200{,}704$. الخطوة 3: لكن فضاء **القنوات** المشترك بين المواقع بُعده 64 (النواة مشتركة مكانياً).

النتيجة: 200,704 خلية لكن البعد الدلالي 64. الربط بالذكاء الاصطناعي: هذا الفرق هو سرّ كفاءة الشبكات الالتفافية: **مشاركة الأوزان** تقيّد الفضاء إلى فضاء جزئي منخفض البعد من فضاء الاتصال الكامل.

مثال (2.1-9): الترميز الموضعي في المحوّلات

المعطيات: نموذج ببعد $d_{model} = 768$، طول السياق 2048، الترميز الموضعي يُضاف للتضمين. المطلوب: هل الجمع يخرج من فضاء التضمين؟

الحل: الخطوة 1: $x = e_{\text{token}} + p_{\text{pos}}$ مع كلٍّ في $\mathbb{R}^{768}$. الخطوة 2: الجمع مغلق في الفضاء (بديهية A1/A2) $\Longrightarrow$ الناتج في $\mathbb{R}^{768}$ ذاته. الخطوة 3: البعد لا يتغيّر، لكن الفضاء المتاح يتوسّع لأن الترميز الموضعي يكسر التماثل.

النتيجة: البعد ثابت 768، والمعلومات تزداد. الربط بالذكاء الاصطناعي: في الترميز الموضعي النسبي الحديث (RoPE) يُطبَّق **تدوير** وليس جمعاً $\Longrightarrow$ التدوير إسometric فيحفظ الأطوال، وهي ميزة عددية كبيرة.

مثال (2.1-10): الاستشعار المضغوط

المعطيات: إشارة $x \in \mathbb{R}^{1000}$ متناثرة: 10 عناصر غير صفرية فقط $(k = 10)$. المطلوب: كم قياساً m نحتاج لاستعادتها؟

الحل: الخطوة 1: x تعيش في اتحاد فضاءات جزئية: $\bigcup_{S:|S|=10} \mathbb{R}^{10}_S$ – اتحاد $\binom{1000}{10}$ فضاءً جزئياً بُعد كلٍّ منها 10. الخطوة 2: كل فضاء جزئي بُعده 10 $\Longrightarrow$ لتمييزه داخل فضاء القياسات نحتاج $m \geq 10$. الخطوة 3: النظرية الدقيقة: $m = O(k\log(n/k)) = O(10\log 100) \approx 100$ قياساً $\Longrightarrow$ ضغط ×10.

النتيجة: ≈ 100 قياساً بدل 1000. الربط بالذكاء الاصطناعي: نفس الفكرة تُستخدم لضغط تحديثات التدرّج في التعلّم الاتحادي (Federated Learning) وإرسال «أهم 1%» فقط.

مثال (2.1-11): عدد الخلايا مقابل رتبة التمثيل

المعطيات: طبقة مخفية بـ h خليةReLU على مدخل $\mathbb{R}^d$. المطلوب: ما أقصى رتبة لمصفوفة التفعيلات على N عيّنة؟

الحل: الخطوة 1: مصفوفة التفعيلات $H \in \mathbb{R}^{N\times h} \Longrightarrow$ رتبتها $\leq \min(N,h)$. الخطوة 2: إذا كان $h < N$ فالتمثيلات كلها تعيش في فضاء جزئي بُعده $\leq h$ من $\mathbb{R}^N$. الخطوة 3: هذا قيدٌ على قدرة الطبقة على «فصل» العيّنات (linear separability in feature space).

النتيجة: الرتبة $\leq h$. الربط بالذكاء الاصطناعي: ظاهرة **«رتبة التمثيل المنهارة»** (representation rank collapse) في الشبكات العميقة تُقاس بهذه الرتبة؛ وهي مؤشر على فقدان التنوّع بين العيّنات.

مثال (2.1-12): بُعد فضاء الصور

المعطيات: صور رمادية 28×28 من MNIST. المطلوب: بُعد فضاء الصور، والبعد الجوهري للمتعدّد الذي تقع عليه.

الحل: الخطوة 1: الفضاء المحيط $\mathbb{R}^{784}$. الخطوة 2: الصور «الحقيقية» لا تملأ الفضاء، بل تقع على متعدّد بُعده $\approx$ 10–15 (تُقدَّر بالـ PCA أو بمقدّر MLE للبعد الجوهري). الخطوة 3: الفرق $784 - 15 = 769$ بُعداً «ضجيج/فراغ».

النتيجة: البعد الجوهري ≈ 15 من أصل 784. الربط بالذكاء الاصطناعي: **فرضية المتعدّد** (manfiold hypothesis): بيانات العالم الحقيقي تعيش على متعدّد منخفض البعد، وهذا ما يبرّر نجاح التعلّم بالتمثيلات وأجهزة التشفير الذاتية (autoencoders).

مثال (2.1-13): hashing feature والاستقلال

المعطيات: 5,000 ميزة أصلية تُضغط بـ hashing إلى 500 بُعداً. المطلوب: هل تحفظ العملية الاستقلال الخطي؟

الحل: الخطوة 1: $x \mapsto Hx$ مع $H \in \mathbb{R}^{500\times 5000} \Longrightarrow$ الرتبة ≤ 500. الخطوة 2: أي 501 ميزة أصلية مستقلة تصبح **تابعة** بالضرورة بعد الضغط (7.2). الخطوة 3: لكن بمتراجحة Johnson–Lindenstrauss تُحفظ المسافات تقريباً إذا كان $500 = O(\log N/\varepsilon^2)$.

النتيجة: الاستقلال يُفقد، والمسافات تُحفظ تقريباً. الربط بالذكاء الاصطناعي: **درس منهجي:** الحفاظ على المسافات (JL) غير الحفاظ على الاستقلال، ومعظم تعلّم الآلة يحتاج الأول لا الثاني.

مثال (2.1-14): تضمينات المستخدمين في نظام توصية

المعطيات: 10 ملايين مستخدم، تضمينات في $\mathbb{R}^{64}$. المطلوب: كم «محوراً دلالياً» مستقلاً يمكن ترميزه؟

الحل: الخطوة 1: البعد 64 $\Longrightarrow$ 64 اتجاهاً مستقلاً على الأكثر. الخطوة 2: عدد النقاط المميّزة بفصل زاوي مريح في $\mathbb{R}^{64}$ $2^{64} \approx$ نظرياً، وعملياً ملايين عدّة. الخطوة 3: لكن **السعة الدلالية** محدودة بـ 64 محوراً $\Longrightarrow$ مميّزات مثل (عمر، قوة شرائية، نوع المحتوى، وقت النشاط...) تتقاسم الأبعاد.

النتيجة: 64 محوراً دلالياً فحسب. الربط بالذكاء الاصطناعي: اختيار بُعد التضمين مقايضة: بعد أكبر $\Longrightarrow$ سعة أعلى وتعميم أسوأ (overfitting) وتكلفة استرجاع أعلى؛ القاعدة العملية $d \approx \sqrt[4]{|\text{الكيانات}|}$.

مثال (2.1-15): تقليل رتبة التدرّجات في التدريب الموزّع

المعطيات: تدرّج طبقة $G \in \mathbb{R}^{4096\times4096}$، نضغطه برتبة $r = 4$ (PowerSGD) قبل الإرسال بين العقد. المطلوب: حجم البيانات المرسَلة ونسبة الضغط.

الحل: الخطوة 1: الحجم الأصلي $4096\times4096 = 16{,}777{,}216$ رقماً. الخطوة 2: التخزين برتبة r: $P \in \mathbb{R}^{4096\times4}$ و $Q \in \mathbb{R}^{4\times4096}$ $\Longrightarrow$ $2 \times 4096 \times 4 = 32{,}768$. الخطوة 3: النسبة $32768/16{,}777{,}216 \approx 0.00195$ $\Longrightarrow$ ضغط $\times512$.

النتيجة: إرسال 0.2% فقط من الحجم. الربط بالذكاء الاصطناعي: الفرضية: تدرّجات التدريب تقع قريباً من فضاء جزئي منخفض الرتبة؛ وهذا تطبيق مباشر لنظرية البعد على **اتصالات** التدريب الموزّع.

6.2.2 أخطاء شائعة

الخطأ	الصواب
«n متجه في $\mathbb{R}^n$ $\Longrightarrow$ مستقلة»	العكس غير صحيح؛ الاستقلال يحتاج فحص المحدّد/الرتبة
الخلط بين المتجهات والفضاء التآلفي	one-hot تعيش في مستوٍ تآلفي لا فضاء خطي
ظنّ أن البعد = عدد المعلمات	البعد = عدد عناصر الأساس؛ المعلمات قد تكون مكرّرة/تابعة
افتراض $\dim(U+W) = \dim U + \dim W$	اطرح $\dim(U\cap W)$ كما في (5.2)

الأهمية: هذه ليست مجرد متراجحة في كتاب جبر، إنها **الأداة التي تُنتج كل حدود الذكاء الاصطناعي**: حدود التعميم، ثوابت ليبشيتز، استقرار التدرّج، وتشابه المتجهات في الاسترجاع الدلالي.

1.3.2 الصياغة الرسمية

متراجحة كوشي–شفارتس (Cauchy–Schwarz): في أي فضاء جداء داخلي:

$$|\langle u,\, v\rangle| \;\le\; \|u\|\,\|v\| \tag{8.2}$$

صيغة الزاوية (التي تُستخدم فعلياً):

$$\cos\theta \;=\; \frac{\langle u,\, v\rangle}{\|u\|\,\|v\|} \;\in\; [-1,\,1] \tag{9.2}$$

حالة التساوي:

$$\big|\langle u, v\rangle\big| = \|u\|\,\|v\| \iff u = \alpha v \text{ أو } v = \mathbf{0} \text{ أو } u = \mathbf{0} \tag{10.2}$$

الصيغة الاحتمالية (متراجحة كوشي–شفارتس للتوقّع):

$$\big(\mathbb{E}[XY]\big)^2 \;\le\; \mathbb{E}[X^2]\,\mathbb{E}[Y^2] \tag{11.2}$$

متراجحة المثلث:

$$\|u+v\| \;\le\; \|u\| + \|v\|, \qquad \big|\|u\| - \|v\|\big| \le \|u - v\| \tag{12.2}$$

الصيغة الماتريسية (متراجحة الناظم الفرعي Sub-multiplicativity — تُعمَّم لاحقاً):

$$\|Ax\| \;\le\; \|A\|_{\mathrm{op}}\,\|x\| \;\le\; \|A\|_F\,\|x\| \tag{13.2}$$

2.3.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
$\langle u, v\rangle$	الجداء الداخلي	$u^{\top}v = \sum_i u_i v_i$	مقياس التشابه الخام
$\|u\|$	الناظم (المدى)	$\sqrt{\langle u, u\rangle}$ = طول المتجه	ناظم L_2
θ	الزاوية بين المتجهين	arccos للنسبة في (9.2)	—
$\cos\theta$	تشابه جيب التمام	في $[-1, 1]$؛ 1= نفس الاتجاه $\Longrightarrow$	cosine_similarity
$[-1, 1]$	مجال التشابه	ناتج مباشر من (8.2)	—
$\mathbb{E}[\cdot]$	التوقّع	المتوسط الاحتمالي	الفصل 15
$\|A\|_{\mathrm{op}}$	الناظم التشغيلي	$\max_{\|x\|=1}\|Ax\|$ = أكبر قيمة مفردة σ_1	الفصل 5
$\|A\|_F$	ناظم فروبنيوس	$\sqrt{\sum_{ij} A_{ij}^2}$	يسهل حسابه
σ_1	أكبر قيمة مفردة	جذر أكبر قيمة ذاتية لـ $A^{\top}A$	مفتاح الاستقرار
α	قياس التناسب	في حالة التساوي (10.2)	استقامة خطية

3.3.2 الشكل الهندسي

شكل (2.2): يساراً: $\langle u, v\rangle = \|u\|\|v\|\cos\theta$، وبما أن $|\cos\theta| \le 1$ تنتج (8.2). يميناً: الضلع المستقيم $\|a+b\|$ أقصر من مجموع الضلعين.

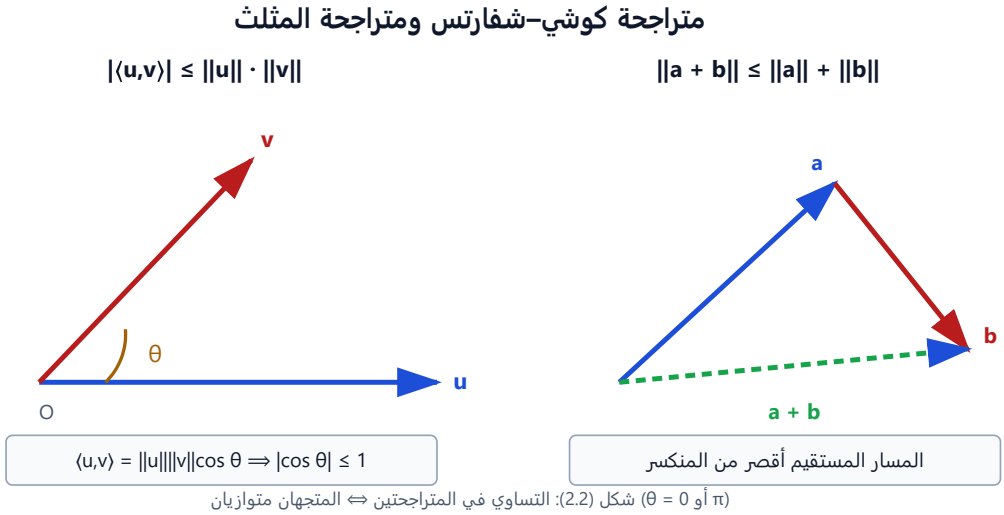
4.3.2 البرهان

كوشي–شفارتس: لكل $\lambda \in \mathbb{R}$، بإيجابية الناظم:

$$0 \;\le\; \|u - \lambda v\|^2 \;=\; \langle u - \lambda v,\; u - \lambda v\rangle \;=\; \|u\|^2 - 2\lambda\langle u, v\rangle + \lambda^2\|v\|^2$$

هذا كثيرُ حدود تربيعي في λ غير سالب $\Longrightarrow$ مميّزه $\le$ صفر (أو نختار $\lambda = \langle u, v\rangle/\|v\|^2$ الذي يصغّره):

$$\arg\min_{\lambda} \;=\; \frac{\langle u, v\rangle}{\|v\|^2} \;\Longrightarrow\; \|u\|^2 - \frac{\langle u, v\rangle^2}{\|v\|^2} \;\ge\; 0 \;\Longrightarrow\; \langle u, v\rangle^2 \le \|u\|^2\|v\|^2$$



شكل ٢.٢: *
كوشي–شفارتس ومتراجحة المثلث

بأخذ الجذر: (8.2)• والتساوي $\|u-\lambda v\|=0 \iff u=\lambda v$ (10.2)• ■
متراجحة المثلث: نربع الطرفين:

$$\|u+v\|^2=\|u\|^2+2\langle u,v\rangle+\|v\|^2 \overset{(2.8)}{\leq} \|u\|^2+2\|u\|\|v\|+\|v\|^2=\big(\|u\|+\|v\|\big)^2$$

5.3.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (2.2-1): تشابه جيب التمام بين تضمينين

المعطيات: $u=(0.6,\,0.8)$، $v=(0.8,\,0.6)$• المطلوب: $\cos\theta$ بينهما، والتحقق من (8.2)•
الحل: الخطوة 1: $\langle u,v\rangle = 0.6\cdot0.8+0.8\cdot0.6 = 0.48+0.48 = 0.96$• الخطوة 2: $\|u\| = \sqrt{0.36+0.64}=1$، $\|v\| = \sqrt{0.64+0.36}=1$• الخطوة 3: $\cos\theta = 0.96/(1\cdot1) = 0.96 \Longrightarrow$ $\theta\approx16.3^\circ$• الخطوة 4: تحقق: $0.96\leq1\cdot1$ ✓•
النتيجة: تشابه عالٍ 96.0 (متجهان متقاربان)• الربط بالذكاء الاصطناعي: هذا هو مقياس الترتيب القياسي في استرجاع المستندات (dense retrieval)؛ الانحراف البسيط يعني «مرادفان» في فضاء التضمين•

مثال (2.2-2): حدّ أعلى على درجات الانتباه

المعطيات: في آلية الانتباه: $\text{score}_{ij}=\frac{q_i^\top k_j}{\sqrt{d}}$ مع $\|q_i\|=3$، $\|k_j\|=5$، $d=64$• المطلوب: أقصى درجة ممكنة•
الحل: الخطوة 1: بـ (8.2): $|q_i^\top k_j|\leq 3\cdot5=15$• الخطوة 2: القسمة على $\sqrt{64}=8 \Longrightarrow |\text{score}|\leq 15/8=1.875$• الخطوة 3: التباين الأقصى لـ softmax = $e^{3.75}\approx42.5$ $\exp(1.875-(-1.875))$•
النتيجة: أقصى نسبة وزنين = 5.42• الربط بالذكاء الاصطناعي: هذا يفسّر **سبب القسمة على** $\sqrt{d}$: بدونها تنفجر الدرجات مع بُعد التضمين فيصبح softmax شبه one-hot ويتلاشى التدرّج•

مثال (2.2-3): حدّ أعلى على ناظم التدرّج

المعطيات: طبقة خطية $z = W^\top x$، $\|x\| = 10$، $\|W\|_F = 2$. المطلوب: حدّ أعلى على $\|\nabla_W \mathcal{L}\|$ إن كان $|\partial \mathcal{L}/\partial z| \le 0.5$.

الحل: الخطوة 1: $\nabla_W \mathcal{L} = x \cdot (\partial \mathcal{L}/\partial z)^\top \Rightarrow \|\nabla_W \mathcal{L}\|_F = \|x\| \cdot |\partial \mathcal{L}/\partial z|$. الخطوة 2: $10 \times 0.5 = 5$. الخطوة 3: تحقق بـ (2.13): النتيجة مستقلة عن $\|W\|_F$ لأن التدرّج على الأوزان يعتمد على المدخل فقط.

النتيجة: $\|\nabla_W \mathcal{L}\| \le 5$. الربط بالذكاء الاصطناعي: هذا الحدّ هو ما يجعل **قصّ التدرّج** (gradient clipping) قابلاً للضبط: نعرف سلفاً مقدار النمو المتوقّع.

مثال (2.2-4): حدّ على ثابت ليبشيتز لطبقة خطية

المعطيات: طبقة $f(x) = Wx$ مع $\|W\|_{\text{op}} = 4$. المطلوب: هل f ليبشيتزية بثابت 4؟ وما أثر ذلك على المتانة؟

الحل: الخطوة 1: $\|f(x) - f(y)\| = \|W(x-y)\| \overset{(2.13)}{\le} \|W\|_{\text{op}} \|x - y\| = 4\|x - y\|$. الخطوة 2: إذن الثابت $L = 4$. الخطوة 3: اضطراب $\|\delta\| = 0.1$ في المدخل $\Rightarrow$ اضطراب ≤ 0.4 في المخرج.

النتيجة: الشبكة 4-ليبشيتزية. الربط بالذكاء الاصطناعي: ثابت ليبشيتز هو المقياس الرسمي لـ **المتانة ضد الأمثلة الخصامية** (adversarial robustness)؛ الطبقات ذات $\|W\|_{\text{op}}$ صغير أكثر متانة، ومنه تقنيات التطبيع الطيفي (spectral normalization).

مثال (2.2-5): هامش SVM وحدّ التعميم

المعطيات: مصنّف خطي $f(x) = \text{sign}(w^\top x)$، $\|w\| = 2$، كل العيّنات $\|x\| \le 5$ ومصنّفة بهامش $w^\top x \ge 1$. المطلوب: حدّ أدنى للهامش الهندسي.

الحل: الخطوة 1: الهامش الهندسي $= \frac{|w^\top x|}{\|w\|}$. الخطوة 2: الحدّ الأدنى $0.5 = 1/2$. الخطوة 3: تحقق بـ (8.2): $|w^\top x| \le 2 \cdot 5 = 10 \Rightarrow$ الهامش ≤ 5 دائماً (مربوط).

النتيجة: الهامش الهندسي $\in [0.5, 5]$. الربط بالذكاء الاصطناعي: حدّ التعميم الكلاسيكي: خطأ الاختبار $\le$ خطأ التدريب + $O\left(\frac{R^2}{\gamma^2 \sqrt{n}}\right)$ حيث R ناظم المدخل و γ الهامش $\Rightarrow$ تكبير الهامش يقلّل فرط التخصيص.

مثال (2.2-6): تنظيم الأوزان وحدّ المخرج

المعطيات: $\|w\|_2 \le 1$ (تنظيم L_2 قوي)، مدخل $\|x\|_2 = 8$. المطلوب: أقصى قيمة مطلقة لـ logit.

الحل: الخطوة 1: بـ (8.2): $|w^\top x| \le 1 \cdot 8 = 8$. الخطوة 2: التساوي يتحقّق فقط إذا كان $x \parallel w$ وبنفس الاتجاه (10.2). الخطوة 3: عملياً الزوايا عشوائية $\Rightarrow$ القيمة المتوقّعة أصغر بكثير: $\mathbb{E}|w^\top x| \approx \|w\|\|x\|/\sqrt{d}$.

النتيجة: الحدّ الأقصى 8، القيمة العملية $8/\sqrt{d} \approx$ ٨. الربط بالذكاء الاصطناعي: هذا هو التفسير الكمّي لأثر weight decay: تصغير $\|w\|$ يصغّر مباشرةً سعة المخرجات $\Longrightarrow$ دالة أنعم $\Longrightarrow$ تعميم أفضل.

مثال (٢.٢-7): تبييض الميزات وارتباط القنوات

المعطيات: ميزتان a, b بتباين 1 ومعامل ارتباط $\rho = 0.9$. المطلوب: التعبير عن الارتباط كجداء داخلي وتحديد مداه.

الحل: الخطوة 1: بعد التوحيد (متوسط 0، تباين 1): $\mathbb{E}[ab] = \langle a, b \rangle = \rho$. الخطوة 2: بـ (٢.١١): $\rho^2 \leq 1 \cdot 1 = 1 \Longrightarrow \mathbb{E}[a^2]\mathbb{E}[b^2] = 1 \Longrightarrow |\rho| \leq 1$ ✓. الخطوة 3: $\rho = 0.9 \Longrightarrow$ الزاوية $\theta = \arccos(0.9) = 25.8°$ $\Longrightarrow$ الميزتان شبه متوازيتين.

النتيجة: الميزتان تحملان معلومات متداخلة بنسبة 81% من التباين. الربط بالذكاء الاصطناعي: التطبيع الدفعي (BatchNorm) وتبييض الميزات يهدفان إلى إزالة هذا التوازي $\Longrightarrow$ تسرّع التقارب لأن سطح الخسارة يصبح أكثر استدارة.

مثال (٢.٢-8): حدّ على تغيّر الخسارة بخطوة تدرّج

المعطيات: $\|\nabla \mathcal{L}\| = 3$؛ خطوة تحديث $\|\Delta\theta\| = 0.01$ بعكس اتجاه التدرّج. المطلوب: حدّ أعلى على تغيّر الخسارة من الدرجة الأولى.

الحل: الخطوة 1: التغيّر من الدرجة الأولى: $\Delta\mathcal{L} \approx \langle \nabla\mathcal{L},\ \Delta\theta \rangle$. الخطوة 2: بـ (٢.٨): $|\Delta\mathcal{L}| \leq 3 \times 0.01 = 0.03$. الخطوة 3: وبما أن الخطوة عكس التدرّج: $\Delta\mathcal{L} \approx -0.03$ (انخفاض).

النتيجة: انخفاض $\leq$ ٠.٠٣ لكل خطوة. الربط بالذكاء الاصطناعي: العلاقة $\Delta\mathcal{L} \leq \eta\|\nabla\|^2$ هي الأساس في إثبات تقارب SGD: نحتاج η صغيراً كفاية لضمان الانخفاض الرتيب.

مثال (٢.٢-9): نمو التدرّج في الشبكات المتكرّرة

المعطيات: RNN: $h_t = \tanh(Wh_{t-1})$؛ $\|W\|_{\text{op}} = 1.5$؛ ناظم الحالة $\|h_0\| = 1$. المطلوب: حدّ على نمو التدرّج بعد $T = 20$ خطوة.

الحل: الخطوة 1: بـ (٢.١٣): $\|Wh\| \leq \|W\|_{\text{op}}\|h\| \leq 1.5\|h\|$. الخطوة 2: بعد T خطوة: $\|h_T\| \leq 1.5^T = 1.5^{20} \approx 3325$. الخطوة 3: التدرّج العكسي يتراكم بنفس العامل $\Longrightarrow$ انفجار.

النتيجة: يُضرب التدرّج بعامل يصل إلى ٣٣٢٥. الربط بالذكاء الاصطناعي: هذا هو التشخيص الكلاسيكي لمشكلة **انفجار/تلاشي التدرّج**؛ والحلول (LSTM/GRU gates، قصّ التدرّج، التطبيع الطيفي) كلها تهدف إلى جعل $\|W\|_{\text{op}} \approx 1$.

مثال (٢.٢-10): حدّ التشابه في استرجاع RAG

المعطيات: استعلام $\|q\| = 1$ بـ q؛ مستند $\|d\| = 1$ بـ d؛ نطاق درجات الاسترجاع. المطلوب: هل يمكن أن تتجاوز الدرجة 1؟ ولماذا تُقسَّم التضمينات؟

الحل: الخطوة 1: بـ (8.2): $|q^\top d| \le 1 \cdot 1 = 1$. الخطوة 2: التساوي $\iff q = d$ تماماً (10.2). الخطوة 3: عملياً تُطبَّع التضمينات (L2-normalize) لتكون $\|\cdot\| = 1 \implies$ الدرجة = $\cos\theta$ مباشرة.

النتيجة: الدرجات $\in [-1, 1]$ بالضبط. الربط بالذكاء الاصطناعي: التطبيع يجعل البحث في الفهرس متريّاً (inner product = cosine)؛ (index وهو شرط لعمل فهارس HNSW و IVF بكفاءة.

مثال (2.2-11): تعارض التدرّجات في التعلّم متعدد المهام

المعطيات: تدرّجان $\|g_1\| = 4$، $\|g_2\| = 6$؛ جداؤهما $\langle g_1, g_2\rangle = -18$. المطلوب: الزاوية بينهما، وهل يتعارضان؟

الحل: الخطوة 1: $\cos\theta = -18/(4 \cdot 6) = -18/24 = -0.75$. الخطوة 2: تحقق من (8.2): $|-18| = 24 \le 18$ ✓. الخطوة 3: $\theta = \arccos(-0.75) \approx 138.6° \implies$ زاوية منفرجة $\implies$ تعارض قوي.

النتيجة: تعارض واضح؛ تحديث أحدهما يضرّ الآخر. الربط بالذكاء الاصطناعي: خوارزميات PCGrad و Gradient Surgery تُسقط تدرّجاً على المتمّم المتعامد للآخر عندما يكون $\cos\theta < 0$ — تطبيق مباشر للإسقاط الذي سنراه في 4.2.

مثال (2.2-12): حدّ على خسارة InfoNCE في التعلّم التبايُني

المعطيات: تضمينات مُطبَّعة $\|v\| = \|u\| = 1$؛ درجة الإيجاب $s_+ = u^\top v = 0.7$؛ درجة السلب الأقصى $s_- = 0.3$؛ درجة الحرارة $\tau = 0.1$؛ عدد السلوب 1000. المطلوب: حدّ أدنى لخسارة InfoNCE.

الحل: الخطوة 1: $\mathcal{L} = -\log \frac{e^{s_+/\tau}}{e^{s_+/\tau} + \sum_i e^{s_i^-/\tau}}$. الخطوة 2: أسوأ حالة: كل السلوب عند أقصى درجة $0.3 \implies$ $1000 \times 0.0183 = \implies e^{-4} = 0.0183$:3 الخطوة .$\mathcal{L} \ge \log\big(1 + 1000\, e^{(0.3-0.7)/0.1}\big) = \log(1 + 1000\, e^{-4})$ $\mathcal{L} \ge \log(19.3) = 2.96 \implies 18.3$.

النتيجة: $\mathcal{L} \ge 2.96$ في أسوأ حالة. الربط بالذكاء الاصطناعي: (8.2) يضمن أن كل الدرجات في $[-1, 1] \implies$ الفرق الأقصى $2/\tau \implies$ عدد السلوب المطلوب لخسارة صغيرة جداً يحدَّد مسبقاً.

مثال (2.2-13): حدّ على ناظم مخرج الانتباه

المعطيات: $\mathrm{Attn}(Q, K, V) = \mathrm{softmax}(QK^\top/\sqrt{d})\, V$؛ A مصفوفة الأوزان (صفوفها توزيعات احتمالية)؛ $\|V\|_{\mathrm{op}} = 3$. المطلوب: حدّ أعلى على ناظم المخرج.

الحل: الخطوة 1: صفوف A توزيعات $\implies \|A\|_\infty = 1$ و $\|A\|_{\mathrm{op}} \le \sqrt{n}$ (لـ n صفوف). الخطوة 2: $\|AV\|_{\mathrm{op}} \le \|A\|_{\mathrm{op}} \|V\|_{\mathrm{op}}$ بـ (13.2). الخطوة 3: $\sqrt{n} \times 3 =$؛ ومع $n = 512$: $67.9 =$.

النتيجة: المخرج مربوط بـ $3\sqrt{n}$. الربط بالذكاء الاصطناعي: هذا يفسّر الحاجة إلى **التوصيلات المتبقّية والتطبيع الطبقي**: بدونها تنمو أنظار المخرج مع طول السياق فتنهار dynamica التدريب.

مثال (2.2-14): متانة التضمينات أمام الضجيج

المعطيات: تضمين x بـ $\|x\| = 2$، ضجيج δ بـ $\|\delta\| = 0.2$، ناظم الأوزان $\|w\| = 1$. المطلوب: أقصى تغيّر في المخرج.

الحل: الخطوة 1: التغيّر $|w^\top(x+\delta) - w^\top x| = |w^\top \delta| \le \|w\|\|\delta\| = 1 \times 0.2 =$ (8.2): الخطوة 2: بـ 0.2. الخطوة 3: نسبة التغيّر إلى المخرج الأقصى $|w^\top x| \le 2 \implies$ 10%.

النتيجة: تغيّر $\le 10\%$ من المخرج. الربط بالذكاء الاصطناعي: تحليل الحساسية هذا هو حجر الأساس في **الخصوصية التفاضلية** (DP): إضافة ضجيج بمقدار مضبوط يحدّد تسريب المعلومات بدقة قابلة للإثبات.

مثال (2.2-15): متراجحة التباين بالصيغة الاحتمالية

المعطيات: متغيّر انحياز النموذج B بتباين 0.04، متغيّر الضجيج E بتباين 0.25، معامل ارتباط ρ. المطلوب: أقصى تغاير ممكن بينهما.

الحل: الخطوة 1: بـ (11.2): $\operatorname{Cov}(B,E)^2 \le \operatorname{Var}(B)\operatorname{Var}(E) = 0.04 \times 0.25 = 0.01$. الخطوة 2: $\implies |\operatorname{Cov}| \le 0.1$. الخطوة 3: تباين الخطأ الكلي $= 0.04 + 0.25 + 2\operatorname{Cov} \le 0.29 + 0.2 = 0.49$.

النتيجة: تباين الخطأ $\in [0.09,\ 0.49]$. الربط بالذكاء الاصطناعي: هذه هي **تحليل الانحياز–التباين–الضجيج**؛ حدّ كوشي–شفارتس على التغاير هو ما يجعل تحليل التحيز–التباين قابلاً للحساب (الفصل 30).

6.3.2 أخطاء شائعة

الخطأ	الصواب
مقارنة cos دون تطبيع الأطوال	$\langle u, v\rangle$ وحده لا يعطي تشابهاً
تطبيق (8.2) على متجهات غير مُطبَّعة وتفسير الناتج كزاوية	الناتج مقياس خام؛ اقسم على الناظمين
نسيان حالة التساوي	التساوي $\iff$ التوازي، وهي مفيدة في إثباتات الحدود
الخلط بين $\|A\|_{\text{op}}$ و $\|A\|_F$	الأول $\le$ الثاني؛ الأول هو الصحيح لحدود ليبشيتز

الأهمية في الذكاء الاصطناعي: هذه النظرية الواحدة تشرح في آنٍ واحد: **الانحدار الخطي، PCA، ضغط الصور، إزالة التحيز من التضمينات، إسقاط التدرّج في التعلّم المستمر، وترشيح كالمان.** كلها «أقرب نقطة في فضاء جزئي».

1.4.2 الصياغة الرسمية

نظرية الإسقاط:

ليكن $W \le V$ فضاءً جزئياً منتهي البعد. لكل $y \in V$ يوجد **وحيد** $\hat{y} \in W$ بحيث:

$$\hat{y} = \arg\min_{w \in W} \|y - w\| \qquad \iff \qquad (y - \hat{y}) \perp W \tag{14.2}$$

أي: $\langle y - \hat{y},\ w \rangle = 0$ لكل $w \in W$. ونكتب $\hat{y} = P_W\, y$.

صيغة الإسقاط الماتريسية: إذا كانت أعمدة $A \in \mathbb{R}^{n \times k}$ أساساً لـ W (أي $W = \mathrm{col}(A)$):

$$P_W \;=\; A\,(A^\top A)^{-1} A^\top \tag{15.2}$$

$$\hat{y} \;=\; P_W\, y \;=\; A\, x^\star, \qquad x^\star \;=\; (A^\top A)^{-1} A^\top y \tag{16.2}$$

المعادلات النظامية (Normal Equations):

$$A^\top A\, x^\star \;=\; A^\top y \tag{17.2}$$

خصائص مؤثّر الإسقاط:

$$P_W^2 = P_W \ \text{(انعكاسية)}, \qquad P_W^\top = P_W \ \text{(تماثل)}, \qquad \mathrm{eig}(P_W) \subseteq \{0, 1\} \tag{18.2}$$

متطابقة فيثاغورس:

$$\|y\|^2 \;=\; \|\hat{y}\|^2 \;+\; \|y - \hat{y}\|^2 \tag{19.2}$$

مترابحة بيسل (Bessel) ومتطابقة بارسيفال (Parseval): لأساس متعامد معياري $\{u_i\}_{i=1}^{n}$:

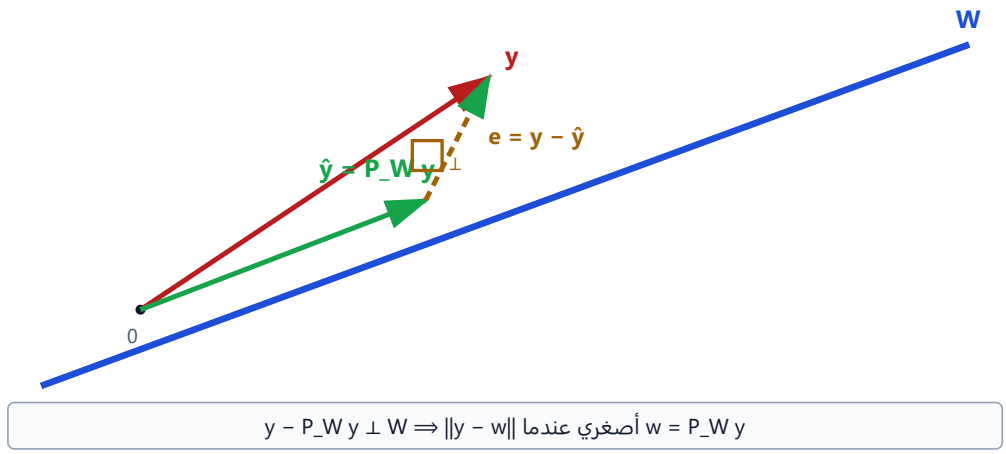
$$\sum_{i=1}^{k} \langle y, u_i \rangle^2 \;\le\; \|y\|^2 \quad (k < n), \qquad \sum_{i=1}^{n} \langle y, u_i \rangle^2 \;=\; \|y\|^2 \tag{20.2}$$

2.4.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
W	فضاء جزئي	فضاء الحلول/النموذج	subspace
P_W	مؤثّر الإسقاط	مصفوفة $n \times n$ تماثلية انعكاسية	matrix projection
$\hat{y}$	الإسقاط/التقدير	أقرب نقطة في W إلى y	y_hat
$e = y - \hat{y}$	الباقي/المخلف	الخطأ الذي لا تستطيع W تمثيله	residual
$\perp$	التعامد	$\langle a, b \rangle = 0$	—
$A^\top A$	مصفوفة غرام	متماثلة موجبة نصف-محددة	عكسها قد يكون غير مستقر
$x^\star$	المعاملات المثلى	حلّ المربعات الصغرى	coefficients
$\arg\min$	مُصغِّر الدالة	النقطة التي تحقّق الأصغريّة	—
eig	مجموعة القيم الذاتية	هنا $\{0, 1\}$	الفصل 4
$\|\cdot\|$	ناظم L_2	الجذر التربيعي لمجموع المربعات	—

3.4.2 الشكل الهندسي

شكل (3.2): المتجه $e = y - \hat{y}$ عمودي على $W \Longrightarrow$ أي حركة داخل W تزيد المسافة (بفيثاغورس). هذا هو معنى «أفضل تقريب».



شكل ٣.٢: *
الإسقاط المتعامد

4.4.2 البرهان

الخطوة 1 — أن الشرط المتعامد يلزم للأصغرية: ليكن $w \in W$ أيّاً. نكتب:

$$y - w \;=\; \underbrace{(y-\hat{y})}_{e} \;+\; \underbrace{(\hat{y}-w)}_{\in W}$$

وبما أن $e \perp W$ و $(\hat{y}-w) \in W$ $\Longrightarrow$ المتجهان متعامدان $\Longrightarrow$ بفيثاغورس:

$$\|y-w\|^2 \;=\; \|e\|^2 \;+\; \|\hat{y}-w\|^2 \;\geq\; \|e\|^2 \;=\; \|y-\hat{y}\|^2$$

والتساوي $\Longleftrightarrow \|\hat{y}-w\|=0 \Longleftrightarrow w=\hat{y}$ $\Longrightarrow$ الأصغرية والوحدانية.

الخطوة 2 — وجود متجه يحقّق التعامد: نطلب $\langle y-Ax,\; a_j\rangle = 0$ لكل عمود a_j من A:

$$A^{\top}(y-Ax) = \mathbf{0} \;\Longrightarrow\; A^{\top}A\,x = A^{\top}y$$

وهو نظام (17.2). وإذا كانت أعمدة A مستقلة فـ $A^{\top}A$ موجبة التحديد $\Longrightarrow$ قابلة للعكس $\Longrightarrow$ $x^{\star}$ وحيد $\Longrightarrow$ (16.2). ■

5.4.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (3.2-1): الانحدار الخطي البسيط كإسقاط

المعطيات: ثلاث نقاط $(1,2),\ (2,3),\ (3,5)$؛ نريد أنسب خط $y = \beta_0 + \beta_1 t$. المطلوب: إيجاد (β_0,β_1) وإثبات أنها إسقاط.

الحل: الخطوة 1: $A = \begin{bmatrix}1 & 1\\ 1 & 2\\ 1 & 3\end{bmatrix}$، الخطوة 2: $y = \begin{bmatrix}2\\3\\5\end{bmatrix}$. $A^{\top}A = \begin{bmatrix}3 & 6\\ 6 & 14\end{bmatrix}$، $A^{\top}y = \begin{bmatrix}10\\23\end{bmatrix}$. الخطوة 3:

نحلّ: $3\beta_0 + 6\beta_1 = 10$، $6\beta_0 + 14\beta_1 = 23$ $\Longrightarrow$ من الأولى ضعفها: $6\beta_0 + 12\beta_1 = 20$ $\Longrightarrow$ بالطرح: $2\beta_1 = 3$ $\Longrightarrow$ $\beta_1 = 1.5$. الخطوة 4: $\beta_0 = (10 - 9)/3 = 1/3$. الخطوة 5: الباقي $e = y - A\beta = (2 - 1.833,\ 3 - 3.333,\ 5 - 4.833) = (0.167,\ -0.333,\ 0.167)$، وتحقق $A^\top e = (0,\ 0)$ ✓ تعامد.

النتيجة: $\hat{y} = 0.333 + 1.5\,t$. الربط بالذكاء الاصطناعي: هذا هو الانحدار الخطي بالمعنى الهندسي: لا توجد «خوارزمية» سوى إيجاد أقرب نقطة من y إلى فضاء الأعمدة $\mathrm{col}(A)$.

مثال (2-3.2): توقّع أسعار المنازل بميزات متعدّدة

المعطيات: 100 منزل، ميزات: المساحة، عدد الغرف، بُعد عن المركز؛ $A \in \mathbb{R}^{100\times 4}$ (مع عمود ثابت). المطلوب: صيغة الحلّ وعدد المعاملات.

الحل: الخطوة 1: $\mathrm{col}(A) = W$، $\dim W = 4$ (بفرض استقلال الأعمدة). الخطوة 2: الحلّ $\beta^\star = (A^\top A)^{-1}A^\top y$. الخطوة 3: بُعد الباقي $= 100 - 4 = 96$ $\Longrightarrow$ الباقي له 96 درجة حرية.

النتيجة: 4 معاملات، 96 درجة حرية للخطأ. الربط بالذكاء الاصطناعي: درجات الحرية المتبقية تحدّد تقدير تباين الضجيج: $\hat{\sigma}^2 = \|e\|^2/(n-k)$، وهي التي تُستخدم في فترات الثقة.

مثال (3-3.2): PCA وخطأ إعادة الإعمار

المعطيات: نقطة $y \in \mathbb{R}^{50}$، نُسقطها على فضاء المركبتين الأوليين $U = \mathrm{span}\{u_1, u_2\}$، الإحداثيات $(4,\ 3)$؛ $\|y\| = 6$. المطلوب: ناظم الباقي ونسبة التباين المفسَّر.

الحل: الخطوة 1: $\|\hat{y}\|^2 = 4^2 + 3^2 = 25 \Longrightarrow \|\hat{y}\| = 5$ (لأن $\{u_1, u_2\}$ متعامد معياري). الخطوة 2: بفيثاغورس (19.2): $\|e\|^2 = 36 - 25 = 11 \Longrightarrow \|e\| = 3.317$. الخطوة 3: نسبة التباين المفسَّر $= 25/36 = 69.4\%$.

النتيجة: 69.4% مفسَّر، و 30.6% خطأ إعادة إعمار. الربط بالذكاء الاصطناعي: هذه هي بالضبط دالة خسارة الـ autoencoder الخطي: $\|y - \hat{y}\|^2$؛ والـ PCA هي الحلّ المغلق له.

مثال (4-3.2): ضغط الصور بإسقاط منخفض الرتبة

المعطيات: صورة رمادية 256×256 $\Longrightarrow$ مصفوفة $M \in \mathbb{R}^{256\times 256}$، نُبقي أول $k = 16$ مركبة مفردة. المطلوب: عدد الأرقام المخزَّنة ونسبة الضغط.

الحل: الخطوة 1: التخزين الكامل $= 256 \times 256 = 65{,}536$ رقماً. الخطوة 2: التخزين برتبة 16: $U_k\Sigma_k \in \mathbb{R}^{256\times 16}$ و $V_k^\top \in \mathbb{R}^{16\times 256}$ $\Longrightarrow$ $2 \times 256 \times 16 = 8{,}192$. الخطوة 3: النسبة $= 8192/65536 = 12.5\%$ $\Longrightarrow$ ضغط $\times 8$. الخطوة 4: الخطأ $= \sqrt{\sum_{i>16}\sigma_i^2}$ (بارسيفال المعمّم).

النتيجة: ضغط $\times 8$ مع خطأ قابل للقياس بدقة. الربط بالذكاء الاصطناعي: هذا هو أساس ضغط أوزان النماذج (SVD-based compression)، ونفس الفكرة تُستخدم لتقليل حجم نماذج اللغة الكبيرة بنسبة 30–50%.

مثال (2.3-5): تقريب دالة بمتعددة حدود

المعطيات: نقاط $\{(0,1),\ (1,3),\ (2,7),\ (3,13)\}$؛ نُقرّبها بمتعددة حدود من الدرجة 2: $p(t) = c_0 + c_1 t + c_2 t^2$. المطلوب: المعاملات بالمربعات الصغرى.

الحل: الخطوة 1: $A = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{bmatrix}$، $y = (1,3,7,13)^\top$. الخطوة 2: $A^\top A = \begin{bmatrix} 4 & 6 & 14 \\ 6 & 14 & 36 \\ 14 & 36 & 98 \end{bmatrix}$، $A^\top y = \begin{bmatrix} 24 \\ 56 \\ 146 \end{bmatrix}$. الخطوة 3: بحلّ النظام: $c_2 = 1$، $c_1 = 1$، $c_0 = 1$ (تحقق: $1 + t + t^2$ تعطي $1, 3, 7, 13$ ✓ تامة).

النتيجة: $p(t) = t^2 + t + 1$ بخطأ صفر. الربط بالذكاء الاصطناعي: تركيب الدوال بأساس متعامد (متعددات حدود ليجاندر/تشيبشيف) هو ما تفعله شبكات KAN الحديثة بدل الأوزان الثابتة.

مثال (2.3-6): توقّع المبيعات من الإنفاق الإعلاني

المعطيات: 6 أشهر: إنفاق $(1,2,3,4,5,6)$ ألف، مبيعات $(3,5,7,9,10,14)$ ألف. المطلوب: خط التوقع والمبيعات المتوقّعة عند إنفاق 7.

الحل: الخطوة 1: $\bar{t} = 3.5$، $\bar{y} = 8$. الخطوة 2: $\sum (t-\bar{t})(y-\bar{y}) = (-2.5)(-5) + (-1.5)(-3) + (-0.5)(-1) + (0.5)(1) + (1.5)(2) + (2.5)(6) = 12.5 + 4.5 + 0.5 + 0.5 + 3 + 15 = 36$. الخطوة 3: $\sum (t-\bar{t})^2 = 17.5 \Rightarrow \beta_1 = 36/17.5 = 2.057$. الخطوة 4: $\beta_0 = 8 - 2.057 \times 3.5 = 0.80$. الخطوة 5: عند $t = 7$: $\hat{y} = 0.80 + 2.057 \times 7 = 15.2$ ألف.

النتيجة: $\approx$ 15,200 وحدة. الربط بالذكاء الاصطناعي: هذا أبسط نموذج تنبؤي؛ كل نموذج تعليمي عميق هو تعميم مرن له: بدلاً من إسقاط على فضاء خطي، نسقط على فضاء **دوال** معلّمة.

مثال (2.3-7): إسقاط التدرّج في التعلّم متعدد المهام (PCGrad)

المعطيات: تدرّجان $g_1 = (1,\ 0)$، $g_2 = (-0.6,\ 0.8)$؛ $\langle g_1, g_2 \rangle = -0.6 < 0$. المطلوب: تعديل g_2 بإسقاطه على نصف الفضاء المتعامد على g_1.

الحل: الخطوة 1: نُسقط g_2 على اتجاه g_1: $\text{proj}_{g_1} g_2 = \frac{\langle g_2, g_1 \rangle}{\|g_1\|^2} g_1 = \frac{-0.6}{1}(1,0) = (-0.6,\ 0)$. الخطوة 2: نطرح المركّبة المتعارضة: $g_2^{\text{proj}} = g_2 - \text{proj}_{g_1} g_2 = (-0.6, 0.8) - (-0.6, 0) = (0,\ 0.8)$. الخطوة 3: تحقق التعامد: $\langle g_1,\ g_2^{\text{proj}} \rangle = 0$ ✓.

النتيجة: التحديث المجمّع $(1,\ 0.8)$ = لا يضرّ المهمة الأولى. الربط بالذكاء الاصطناعي: خوارزمية PCGrad تُطبّق هذا الشرط لكل زوج من المهام، وقد أثبتت تحسّناً ملموساً في التعلّم متعدد المهام والروبوتات.

مثال (2.3-8): الإسقاط على المبسط (Simplex) في التعلّم التعزيزي

المعطيات: متجه $v = (0.5,\ 0.3,\ 0.4)$؛ نريد إسقاطه على المبسط الاحتمالي $\Delta = \{p : \sum p_i = 1,\ p_i \geq 0\}$. المطلوب: أقرب توزيع احتمالي إلى v.

الحل: الخطوة 1: المجموع $= 1.2$؛ نطرح الزائد: نبحث θ بحيث $\sum \max(v_i - \theta,\ 0) = 1$. الخطوة 2: جرّب $\theta = 0.1$: $(0.4,\ 0.2,\ 0.3)$ $\Longrightarrow$ المجموع $= 0.9$ $\Longrightarrow$ θ كبير. الخطوة 3: جرّب $\theta = 0.05$: $(0.45, 0.25, 0.35)$ $\Longrightarrow$ المجموع $= 1.05$ $\Longrightarrow$ أصغر قليلاً. الخطوة 4: بالاستقراء: $\theta = 0.0667$ $\Longrightarrow$ $(0.4333,\ 0.2333,\ 0.3333)$ $\Longrightarrow$ المجموع $= 1.0$ ✓.

النتيجة: $p^\star = (0.433,\ 0.233,\ 0.333)$. الربط بالذكاء الاصطناعي: الإسقاط على المبسط يظهر في تحديثات السياسات الاحتمالية (TRPO/PPO) وفي خسارة الإنتروبيا؛ وله خوارزمية $O(n \log n)$ دقيقة.

مثال (2.3-9): ترشيح كالمان كإسقاط متكرّر

المعطيات: قياس $z = 10$، تقدير سابق $\hat{x}^- = 8$؛ تباينات: $P^- = 4$، $R = 1$. المطلوب: التقدير المحدَّث بربح كالمان.

الحل: الخطوة 1: ربح كالمان $K = \frac{P^-}{P^- + R} = \frac{4}{5} = 0.8$. الخطوة 2: $\hat{x} = \hat{x}^- + K(z - \hat{x}^-) = 8 + 0.8 \times 2 = 9.6$. الخطوة 3: التباين المحدَّث $P = (1 - K)P^- = 0.2 \times 4 = 0.8$. الخطوة 4: التفسير الهندسي: K هو وزن الإسقاط على المدى الجديد مقابل الفضاء السابق.

النتيجة: $\hat{x} = 9.6$ بتباين 0.8. الربط بالذكاء الاصطناعي: كالمان هو المربعات الصغرى المُعمَّمة على فضاء **حالات** زمنية؛ ويُستخدم اليوم في تتبّع الأجسام في القيادة الذاتية ودمج المستشعرات.

مثال (2.3-10): معايرة مستشعر حرارة بـ 3 قراءات

المعطيات: مستشعر يعطي $(20.1,\ 20.3,\ 19.8)$ عند درجة حرارة مرجعية معلومة 20.0. المطلوب: تقدير الانحياز والضجيج.

الحل: الخطوة 1: نموذج القياس: $z_i = \theta + \varepsilon_i$، أي $A = (1, 1, 1)^\top$، $W = \text{span}\{(1, 1, 1)\}$. الخطوة 2: الإسقاط: $\hat{\theta} = \frac{A^\top z}{A^\top A} = \frac{60.2}{3} = 20.067$، $e = (-0.033,\ 0.233,\ -0.267)$؛ $\|e\|^2 = 0.0011 + 0.0543 + 0.0713 = 0.127$. الخطوة 4: تباين الضجيج $= 0.127/2 = 0.063$ $\Longrightarrow$ انحراف معياري $\sigma \approx 0.25°$، ضجيج $\approx 0.25°$+. الربط بالذكاء الاصطناعي: تقدير الانحياز هو إسقاط على فضاء «الثوابت»، ونفس التقنية تُستخدم لمعايرة logits الشبكة (temperature scaling).

مثال (2.3-11): LoRA كإسقاط للتحديث على فضاء منخفض الرتبة

المعطيات: تحديث كامل $\Delta W \in \mathbb{R}^{4096\times4096}$ برتبة فعلية 2، القيم المفردة $(10,\ 4)$. المطلوب: أفضل تقريب برتبة 1 والخطأ.

الحل: الخطوة 1: بأقرب تقريب منخفض الرتبة (Eckart–Young، الفصل 4): نُبقي أكبر قيمة مفردة $\Rightarrow$ الرتبة 1. الخطوة 2: خطأ فروبنيوس $= \sqrt{\sum_{i>1}\sigma_i^2} = \sqrt{16} = 4$. الخطوة 3: الطاقة المحتفظ بها $= 100/(100+16) = 86.2\%$.

النتيجة: رتبة 1 تحفظ 86% من التحديث. الربط بالذكاء الاصطناعي: هذا يبرّر عملياً نجاح LoRA برتبة 1–8: تحديثات الضبط الدقيق مركّزة جداً طيفياً.

مثال (2.3-12): التعلّم المستمر بإسقاط التدرّج المتعامد (OGD)

المعطيات: المهمة 1 تعلّمت فضاءً جزئياً S ببعد 10 من أصل $d = 100$؛ تدرّج المهمة 2 هو $g \in \mathbb{R}^{100}$. المطلوب: تحديث لا يضرّ المهمة 1.

الحل: الخطوة 1: ليكن $U \in \mathbb{R}^{100\times10}$ أساساً متعاماً معيارياً لـ S. الخطوة 2: الإسقاط: $P_S g = UU^\top g$. الخطوة 3: التحديث الآمن: $g^\perp = g - P_S g = (I - UU^\top)g$. الخطوة 4: تحقق: $\langle g^\perp,\ s\rangle = 0$ لكل $s \in S$ ✓.

النتيجة: تحديث في المتمّم المتعامد $\Rightarrow$ لا يتداخل مع المهمة 1. الربط بالذكاء الاصطناعي: OGD و Adam-NSCL من أشهر طرق مقاومة **النسيان الكارثي** (catastrophic forgetting)؛ جوهرها الإسقاط المتعامد نفسه.

مثال (2.3-13): إزالة التحيز من التضمينات اللغوية

المعطيات: تضمين كلمة w، اتجاه التحيز g (مثل «ذكر–أنثى») بـ $\|g\| = 1$. المطلوب: إزالة مركّبة التحيز من w.

الحل: الخطوة 1: الإسقاط على اتجاه التحيز: $\text{proj}_g w = (w^\top g)\, g$. الخطوة 2: الطرح: $w^{\text{debias}} = w - (w^\top g)g$. الخطوة 3: تحقق التعامد: $(w^{\text{debias}})^\top g = w^\top g - (w^\top g)(g^\top g) = 0$ ✓. الخطوة 4: إعادة التطبيع: $w^{\text{debias}}/\|w^{\text{debias}}\|$.

النتيجة: تضمين خالٍ من مركّبة التحيز المعرَّفة. الربط بالذكاء الاصطناعي: هذه خوارزمية Bolukbasi et al. (2016) الشهيرة، Debiasing، وهي تطبيق حرفي لنظرية الإسقاط على أخلاقيات الذكاء الاصطناعي.

مثال (2.3-14): توقّع استهلاك الطاقة لمبنى

المعطيات: 12 شهراً، ميزتان: متوسط الحرارة (h) وعدد الأيام (d)، استهلاك y، أُعطي $A^\top A = \begin{bmatrix}12 & 0\\ 0 & 12\end{bmatrix}$ (ميزات متعامدة!) و $A^\top y = \begin{bmatrix}240\\ 36\end{bmatrix}$. المطلوب: المعاملات، ولماذا الحلّ أبسط هنا.

الحل: الخطوة 1: بما أن $A^\top A = 12I \Rightarrow (A^\top A)^{-1} = \frac{1}{12}I$. الخطوة 2: $\beta^\star = \frac{1}{12}\begin{bmatrix}240\\ 36\end{bmatrix} = \begin{bmatrix}20\\ 3\end{bmatrix}$. الخطوة 3: الدرس: تعامد الميزات يجعل كل معامل يُحسب مستقلاً.

النتيجة: الاستهلاك $3d + 20 =$ (بوحدات مناسبة). الربط بالذكاء الاصطناعي: هذا هو سبب شيوع **تبييض الميزات** و decorrelation قبل الانحدار: يجعل المصفوفة قطرية فيزول الترابط العددي وتتسارع كل خوارزميات التحسين.

مثال (2.3-15): كشف الشذوذ بناظم الباقي

المعطيات: نموذج الفضاء الجزئي W ببعد 3 في $\mathbb{R}^{20}$ من عيّنات سليمة، عتبة الباقي 5.0؛ عيّنة جديدة y بـ $\|y\| = 5$ و $\|P_W y\| = 4.2$. المطلوب: هل العيّنة شاذّة؟

الحل: الخطوة 1: بفيثاغورس (19.2): $\|e\|^2 = \|y\|^2 - \|P_W y\|^2 = 25 - 17.64 = 7.36$. الخطوة 2: $\|e\| = 2.71$. الخطوة 3: $2.71 > 0.5 \Longrightarrow$ شاذّة.

النتيجة: شذوذ مؤكَّد بباقي 2.71. الربط بالذكاء الاصطناعي: تقنيات detection anomaly PCA-based و detection reconstruction-error في autoencoders تعمل بهذه الآلية بالضبط: ما لا يستطيع النموذج «إعادة بنائه» هو الشاذ.

6.4.2 أخطاء شائعة

الخطأ	الصواب
عكس $A^\top A$ عند تبعية الأعمدة	استخدم المعكوس الزائف (pseudo-inverse) أو التنظيم
افتراض أن إسقاطاً على أساس غير متعامد = مجموع الإسقاطات	صحيح فقط لأساس متعامد معياري (بارسيفال)
تجاهل شرط $\perp$	بدون التعامد لا تكون النقطة هي الأقرب (14.2)
حساب $\|e\|$ كفرق الناظمين	استخدم فيثاغورس: $\|e\|^2 = \|y\|^2 - \|\hat{y}\|^2$

الأهمية: كل مرة تريد فيها «محاور مستقلة تماماً» في بياناتك — تبييض، تهيئة أوزان، إزالة تعدد خطي، حساب مستقر للمربعات الصغرى — فأنت تستخدم غرام–شميدت، حتى لو لم تكتبه بيدك.

1.5.2 الصياغة الرسمية

خوارزمية غرام–شميدت: ليكن $\{v_1, \dots, v_k\}$ مستقلاً خطياً في فضاء جداء داخلي. نُعرّف بالتدرّج:

$$w_1 = v_1, \qquad u_1 = \frac{w_1}{\|w_1\|} \tag{21.2}$$

$$w_j = v_j - \sum_{i=1}^{j-1} \langle v_j,\, u_i \rangle\, u_i, \qquad u_j = \frac{w_j}{\|w_j\|}, \quad j = 2, \dots, k \tag{22.2}$$

النتيجة — التحليل QR: لأي $A \in \mathbb{R}^{m \times n}$ $(m \geq n)$ بأعمدة مستقلة يوجد وحيداً:

$$A = Q\,R, \qquad Q^\top Q = I_n, \qquad R \text{ مثلثية عليا بقطر موجب} \tag{23.2}$$

حيث عناصر R:

$$R_{ij} = \langle v_j,\, u_i \rangle \ (i < j), \qquad R_{jj} = \|w_j\| > 0 \tag{24.2}$$

خاصية حفظ الأطوال (Isometry):

$$\forall x \in \mathbb{R}^n: \quad \|Qx\| = \|x\|, \qquad \|A\|_F = \|R\|_F \tag{25.2}$$

حلّ المربعات الصغرى بـ QR (أكثر استقراراً من المعادلات النظامية):

$$Rx^\star = Q^\top y \tag{26.2}$$

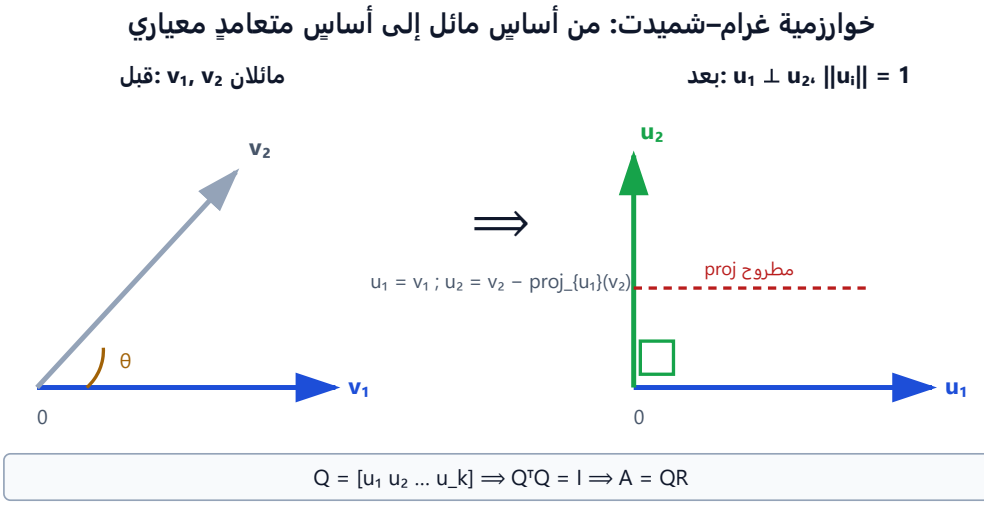
النسخة المعدّلة (Modfiied) Gram–Schmidt — المستخدمة عملياً:

$$v_j \leftarrow v_j - \langle v_j, u_i \rangle u_i \quad \text{فوراً بعد حساب كل } u_i \quad \text{لكل } i: \tag{27.2}$$

2.5.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
v_j	متجه المدخل	العمود j من A	قد يكون مائلاً/مترابطاً
w_j	المتجه المتبقّي	v_j بعد طرح إسقاطاته على السابقين	قبل التطبيع
u_j	المتجه المتعامد المعياري	$\|u_j\| = 1$، $u_j \perp u_i$	العمود j من Q
Q	مصفوفة متعامدة	$Q^\top Q = I$	أعمدة متعامدة معيارية
R	مثلثية عليا	تحمل الإحداثيات	تُحلّ بالتعويض العكسي
$R_{jj} > 0$	القطر الموجب	شرط الوحدانية لـ QR	—
$\|\cdot\|_F$	ناظم فروبنيوس	محفوظ تحت الضرب بـ Q	(25.2)
$O(mn^2)$	تكلفة غرام–شميدت	نفس تكلفة QR	—
$\kappa_2(A)$	عدد الحالة الشرطية	$\kappa_2(A) = \kappa_2(R)$؛ المعادلات النظامية تُربيعه κ^2	سبب اختيار QR

3.5.2 الشكل الهندسي



شكل ٤.٢: *
غرام–شميدت

شكل (4.2): من متجهين مائلين إلى متجهين متعامدين معياريين بطرح إسقاط v_2 على u_1.

4.5.2 البرهان

الاستقراء على j: الأساس $j=1$: $w_1 = v_1 \neq \mathbf{0}$ (لأن المجموعة مستقلة) $\Rightarrow u_1$ معرَّف و $\|u_1\| = 1$.

الخطوة: لنفترض $u_1, \dots, u_{j-1}$ متعامدة معيارية وتولّد نفس فضاء $v_1, \dots, v_{j-1}$. نُعرّف w_j بـ (22.2). نُثبت التعامد: لكل $i < j$:

$$\langle w_j,\ u_i \rangle \;=\; \langle v_j,\ u_i \rangle \;-\; \sum_{\ell<j} \langle v_j, u_\ell \rangle \underbrace{\langle u_\ell, u_i \rangle}_{=\delta_{\ell i}} \;=\; \langle v_j, u_i \rangle - \langle v_j, u_i \rangle \;=\; 0$$

ولو كان $w_j = \mathbf{0}$ لكان $v_j \in \operatorname{span}\{u_1,\dots,u_{j-1}\} = \operatorname{span}\{v_1,\dots,v_{j-1}\}$ $\Rightarrow$ تناقض مع الاستقلال $\Rightarrow w_j \neq \mathbf{0} \Rightarrow u_j$ معرَّف.

التحليل QR: من (22.2): $v_j = \sum_{i<j} \langle v_j, u_i \rangle u_i + \|w_j\| u_j = \sum_{i \le j} R_{ij} u_i$، وهو بالضبط العمود j من QR. و R مثلثية عليا لأن $R_{ij} = 0$ لـ $i > j$. ■

ملاحظة عددية مهمة:

غرام–شميدت الكلاسيكي يفقد التعامد بسبب أخطاء الفاصلة العائمة؛ النسخة المعدّلة (27.2) أفضل، وتحويلات Householder (انعكاسات) هي الأكثر استقراراً وتُستخدم في LAPACK.

5.5.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (4.2-1): غرام–شميدت على متجهين في $\mathbb{R}^2$

المعطيات: $v_1 = (3, 1)$، $v_2 = (2, 2)$. المطلوب: أساس متعامد معياري.

الحل: الخطوة 1: $u_1 = v_1/\|v_1\| = (3,1)/\sqrt{10} = (0.9487,\ 0.3162)$. الخطوة 2: $\langle v_2, u_1 \rangle = 2(0.9487) + 2(0.3162) = 1.8974 + 0.6324 = 2.5298$. الخطوة 3: $w_2 = v_2 - 2.5298\, u_1 = (2, 2) - (2.4,\ 0.8) = (-0.4,\ 1.2)$. الخطوة 4: $\|w_2\| = \sqrt{0.16 + 1.44} = \sqrt{1.6} = 1.2649 \Rightarrow u_2 = (-0.3162,\ 0.9487)$. الخطوة 5: تحقق: $\langle u_1, u_2 \rangle = -0.3 + 0.3 = 0$ ✓.

النتيجة: $\{u_1, u_2\}$ أساس متعامد معياري لـ $\mathbb{R}^2$. الربط بالذكاء الاصطناعي: هذه العملية هي نواة كل خوارزمية تبييض (whitening) وتُطبَّق على دفعات الميزات قبل التغذية للشبكة.

مثال (4.2-2): تحليل QR لمصفوفة 2×2

المعطيات: $A = \begin{bmatrix} 3 & 2 \\ 1 & 2 \end{bmatrix}$ بأعمدة v_1, v_2 من المثال السابق. المطلوب: كتابة $A = QR$ صريحة.

الحل: الخطوة 1: $Q = [u_1\ u_2] = \begin{bmatrix} 0.9487 & -0.3162 \\ 0.3162 & 0.9487 \end{bmatrix}$. الخطوة 2: $R_{11} = \|v_1\| = \sqrt{10} = 3.1623$؛ $R_{12} = \langle v_2, u_1 \rangle = 2.5298$، $R_{22} = \|w_2\| = 1.2649$. الخطوة 3: $R = \begin{bmatrix} 3.1623 & 2.5298 \\ 0 & 1.2649 \end{bmatrix}$. الخطوة 4: تحقق: العمود الأول Q: $3.1623\, u_1 = (3, 1)$ ✓.

النتيجة: تحليل QR كامل. الربط بالذكاء الاصطناعي: مكتبات مثل numpy.linalg.qr و torch.linalg.qr تُعيد هذا بالضبط، ويُستخدم لحلّ الأنظمة داخل طبقات «المربعات الصغرى القابلة للتفاضل».

مثال (2.4.3): تهيئة أوزان متعامدة في RNN

المعطيات: مصفوفة recurrent $W \in \mathbb{R}^{h \times h}$ بـ $h = 512$، نُريد $\|W\|_{\text{op}} = 1$ بالضبط. المطلوب: كيف نبنيها؟

الحل: الخطوة 1: نولّد G بمدخلات غاوسية قياسية. الخطوة 2: نُطبّق QR: $G = QR \Longrightarrow$ نأخذ $W = Q$. الخطوة 3: حينئذٍ $W^\top W = I \Longrightarrow$ كل القيم المفردة $= 1 \Longrightarrow \|W\|_{\text{op}} = 1$. الخطوة 4: يحفظ W أطوال الحالات المخفية $\Longrightarrow$ لا انفجار ولا تلاشٍ في الحالة الخطية.

النتيجة: تهيئة تحفظ الطاقة. الربط بالذكاء الاصطناعي: التهيئة المتعامدة (Orthogonal/Unitary init) هي العلاج الكلاسيكي لمشكلة التدرّجات في الشبكات المتكرّرة العميقة، وتُستخدم اليوم في RNN و ResNet وحتى في بعض طبقات الانتباه.

مثال (2.4.4): استقرار QR مقابل المعادلات النظامية

المعطيات: A عدد حالة شرطيتها $\kappa_2(A) = 10^6$. المطلوب: مقارنة فقدان الدقة بين الحلّين.

الحل: الخطوة 1: المعادلات النظامية تحسب $A^\top A \Longrightarrow \kappa_2(A^\top A) = \kappa_2(A)^2 = 10^{12}$. الخطوة 2: QR يحسب R مع $\kappa_2(R) = \kappa_2(A) = 10^6$. الخطوة 3: بدقة مضاعفة ($\varepsilon \approx 2.2 \times 10^{-16}$): الخطأ النسبي $\approx \varepsilon\kappa \Longrightarrow 2.2 \times 10^{-4}$ للمعادلات النظامية مقابل 2.2×10^{-10} لـ QR.

النتيجة: QR أدقّ بستة مراتب عشرية. الربط بالذكاء الاصطناعي: في تدريب الشبكات بميزات مترابطة (صور، تضمينات) قد ينهار الحلّ المباشر، ولهذا تستخدم المكتبات QR أو SVD أو Cholesky مع تنظيم.

مثال (2.4.5): إزالة التعدد الخطي في ميزات الانحدار

المعطيات: ثلاث ميزات: المساحة بالمتر^2، المساحة بالقدم^2، عدد الغرف. الأولى والثانية مرتبطتان خطياً تماماً. المطلوب: معالجة قبل الانحدار.

الحل: الخطوة 1: $A^\top A$ منفردة $\Longrightarrow$ المعكوس غير موجود $\Longrightarrow$ المعادلات النظامية تفشل. الخطوة 2: غرام-شميدت يكتشف ذلك: عند $j = 3$ يصبح $w_3 \approx \mathbf{0} \Longrightarrow \|w_3\| < \tau$. الخطوة 3: نُسقط العمود التابع $\Longrightarrow$ نحصل على أساس مستقل $\Longrightarrow$ نحلّ بطريقة stable.

النتيجة: ميزتان فعّاليتان بدل ثلاث. الربط بالذكاء الاصطناعي: التشخيص التلقائي بـ $\|w_j\|$ الصغير هو أساس كشف multicollinearity، وبديله الإحصائي هو عامل تضخّم التباين VIF.

مثال (2.4.6): بناء مرشحات التفافية متعامدة

المعطيات: 64 مرشحاً بحجم $3 \times 3 \times 32 \Longrightarrow$ كل مرشح متجه في $\mathbb{R}^{288}$. المطلوب: جعل المرشحات متعامدة ولماذا ذلك مفيد.

الحل: الخطوة 1: نُرصّ المرشحات كصفوف $F \in \mathbb{R}^{64\times 288}$. الخطوة 2: نُطبّق غرام-شميدت (أو تنظيمًا متعامداً أثناء التدريب) $\Longrightarrow FF^\top = I$. الخطوة 3: الفائدة: خرائط الميزات الناتجة غير مترابطة $\Longrightarrow$ معلومات غير مكرّرة. الخطوة 4: وتحسّن استقرار التدرّج لأن $\|F\|_{\text{op}} = 1$.

النتيجة: تمثيل أكثر كفاءة واستقراراً. الربط بالذكاء الاصطناعي: «التهيئة المتعامدة للمرشحات» و «Orthogonal Convolutional Neural Networks» أثبتت متانة أعلى أمام الأمثلة الخصامية.

مثال (2.4-7): حساب الحجم/المحدد بطريقة مستقرة

المعطيات: $A \in \mathbb{R}^{n\times n}$ قابلة للعكس. المطلوب: حساب $|\det A|$ بـ QR.

الحل: الخطوة 1: $\det A = \det Q \cdot \det R = (\pm 1) \cdot \prod_{j=1}^{n} R_{jj}$. الخطوة 2: إذن $|\det A| = \prod_j R_{jj}$ $= \prod_j \|w_j\|$. الخطوة 3: الحجم المتوازي السطوح = جداء أطوال المتعامدات (تفسير هندسي مباشر). الخطوة 4: ولأجل الاستقرار نحسب $\log|\det A| = \sum_j \log R_{jj}$ فنتجنّب التجاوز/التلاشي العددي.

النتيجة: حساب مستقر للمحدد عبر اللوغاريتم. الربط بالذكاء الاصطناعي: النماذج التدفقية (Normalizing Flows) تحسب بالضبط $\log|\det J|$ لتغيّر المتغيّرات؛ والـ QR/LU هي طرق حسابها.

مثال (2.4-8): خوارزمية QR للقيم الذاتية

المعطيات: مصفوفة متماثلة $S \in \mathbb{R}^{200\times 200}$، نريد قيمها الذاتية. المطلوب: مخطط الخوارزمية وسبب نجاحها.

الحل: الخطوة 1: كرّر: $S_k = Q_k R_k$ (QR) ثم $S_{k+1} = R_k Q_k$. الخطوة 2: بما أن $S_{k+1} = Q_k^\top S_k Q_k \Longrightarrow$ S_{k+1} **مشابهة** لـ $S_k \Longrightarrow$ نفس القيم الذاتية. الخطوة 3: مع التكرار يتقارب S_k إلى مصفوفة مثلثية عليا $\Longrightarrow$ القيم الذاتية على القطر. الخطوة 4: مع انزياحات (shfits) يتسارع التقارب $\Longrightarrow$ خوارزمية QR المستخدمة في LAPACK.

النتيجة: قيم ذاتية بدقة عالية. الربط بالذكاء الاصطناعي: حساب القيم الذاتية للهسيّة (Hessian) ضروري في تحليل سطح الخسارة؛ وخوارزمية QR هي العمود الفقري لـ numpy.linalg.eig.

مثال (2.4-9): محاذاة فضاءات التضمين بين لغتين (Orthogonal Procrustes)

المعطيات: تضمينات إنجليزية $X \in \mathbb{R}^{N\times d}$ وعربية $Y \in \mathbb{R}^{N\times d}$ لنفس الكلمات (قاموس ثنائي اللغة). المطلوب: مصفوفة تدوير R بأفضل محاذاة.

الحل: الخطوة 1: نُشكّل $M = X^\top Y$ ونحسب SVD: $M = U\Sigma V^\top$. الخطوة 2: الحلّ الأمثل للمسألة المتعامدة: $R^\star = UV^\top$ (مصفوفة متعامدة). الخطوة 3: نُطبّق $XR^\star$ فتقترب من Y. الخطوة 4: الخسارة الدنيا $= \|X\|_F^2 + \|Y\|_F^2 - 2\sum_i \sigma_i$.

النتيجة: محاذاة خطية متعامدة مثلى. الربط بالذكاء الاصطناعي: هذه هي خوارزمية محاذاة التضمينات عبر اللغات (MUSE, VecMap)؛ وتُستخدم لنقل النماذج بين اللغات دون بيانات متوازية.

مثال (2.4.10): تبييض الميزات (Whitening) بخطوات غرام-شميدت

المعطيات: دفعة ميزات $X \in \mathbb{R}^{1000\times 50}$ بمتوسط صفري ومصفوفة تغاير Σ. المطلوب: تحويل يجعل التغاير I.
الحل: الخطوة 1: نحلّل $\Sigma = U\Lambda U^\top$ (قيم ذاتية). الخطوة 2: التبييض: $Z = X U\Lambda^{-1/2}U^\top$ (ZCA) أو $Z = X U\Lambda^{-1/2}$ (PCA-whitening). الخطوة 3: تحقق: $\mathrm{Cov}(Z) = \Lambda^{-1/2}U^\top\Sigma U\Lambda^{-1/2} = I$ ✓. الخطوة 4: الزوايا بين الميزات بعد التبييض تصبح $90°$ $\Longrightarrow$ دلالة غرام-شميدت المعمّمة.
النتيجة: ميزات غير مترابطة بتباين 1. الربط بالذكاء الاصطناعي: التبييض يُسرّع تدريب الشبكات العميقة جداً (وهو جوهر BatchNorm و LayerNorm و ICA ويحسّن توزيع القيم المفردة.

مثال (2.4.11): بناء قاموس متعامد للضغط

المعطيات: نريد ضغط إشارات في $\mathbb{R}^{64}$ بـ 8 اتجاهات فقط. المطلوب: مقارنة قاموس عشوائي بآخر متعامد.
الحل: الخطوة 1: قاموس عشوائي $D \Longrightarrow D^\top D \neq I \Longrightarrow$ الاستعادة تحتاج عكس مصفوفة غرام (غير مستقر). الخطوة 2: قاموس متعامد $Q \Longrightarrow$ الاستعادة $= Q^\top x$ بضربة واحدة ودون عكس. الخطأ في الحالتين متقارب، لكن التكلفة: $O(k^3)$ مقابل $O(k^2)$. الخطوة 4: وعدد الحالة = 1 للمتعامد $\Longrightarrow$ لا تضخيم للضجيج.
النتيجة: المتعامد أرخص وأكثر استقراراً. الربط بالذكاء الاصطناعي: «التنظيم المتعامد» (orthogonal regularization) يُستخدم في أجهزة التشفير الذاتية لمنع انهيار القاموس، وفي ضغط النماذج.

مثال (2.4.12): فصل الإشارة عن الضجيج بأساس متعامد

المعطيات: إشارة s في فضاء جزئي S ببعد 5 من $\mathbb{R}^{100}$، قياس $y = s + n$ مع ضجيج $\|n\| = 2$ متعامد على S. المطلوب: تقدير s والخطأ المتبقي.
الحل: الخطوة 1: نبني أساساً متعامداً معيارياً $U \in \mathbb{R}^{100\times 5}$ لـ S (بغرام-شميدت). الخطوة 2: الإسقاط: $\hat{s} = UU^\top y = UU^\top(s+n) = s + UU^\top n = s$ (لأن $n \perp S$). الخطوة 3: الاستعادة تامة! الخطأ $= 0$. الخطوة 4: إن لم يكن الضجيج متعامداً تماماً: $\|خطأ\| = \|UU^\top n\| \leq \|n\| = 2$.
النتيجة: استعادة تامة للإشارة. الربط بالذكاء الاصطناعي: هذا هو مبدأ **ترشيح الضجيج بالفضاء الجزئي** (subspace filtering) المستخدم في تحسين الكلام وفي إزالة ضجيج الصور الطبية.

مثال (2.4.13): ضمان ليبشيتز = 1 بطبقة متعامدة

المعطيات: طبقة $f(x) = Wx$، نريد $\|f(x) - f(y)\| = \|x - y\|$ تماماً (حفظ المسافات). المطلوب: شرط على W.
الحل: الخطوة 1: الحفظ $\Longleftrightarrow \|Wz\|^2 = \|z\|^2$ لكل $z \Longleftrightarrow z^\top(W^\top W)z = z^\top z$. الخطوة 2: $\Longleftrightarrow W^\top W = I$ $\Longrightarrow W$ متعامدة (إن كانت مربعة). الخطوة 3: بـ QR: أي مصفوفة قابلة للعكس تُحوَّل إلى متعامدة

بأخذ عامل Q. الخطوة 4: الأثر: الشبكة 1-ليبشيتزية $\Longrightarrow$ شهادة متانة خصامية مجانية.
النتيجة: حفظ المسافات $\Longleftrightarrow$ التعامد. الربط بالذكاء الاصطناعي: «الشبكات 1-ليبشيتزية» (Parseval networks) تفرض $W^\top W = I$ أثناء التدريب فتحصل على متانة مضمونة أمام الأمثلة الخصامية.

مثال (14-4.2): بناء مساحة كامن منتظمة في VAE

المعطيات: فضاء كامن $\mathbb{R}^{32}$؛ نلاحظ أن 8 أبعاد فقط «نشطة» (posterior collapse). المطلوب: تشخيص وعلاج بغرام–شميدت.
الحل: الخطوة 1: نحسب تغاير الترميزات $\mathrm{Cov}(z)$؛ نجد رتبتها 8 $\Longrightarrow$ 24 بُعداً تابعاً. الخطوة 2: نُطبّق غرام–شميدت على اتجاهات التباين $\Longrightarrow$ نحدد الأساس الفعّال. الخطوة 3: العلاج: زيادة وزن مصطلح KL أو استخدام توزيع سابق أكثر مرونة (VampPrior). *الخطوة 4: أو إعادة تعيين الأبعاد بالأساس المتعامد الجديد $\Longrightarrow$ استخدام كامل للسعة.
النتيجة: تشخيص كمّي للانهيار. الربط بالذكاء الاصطناعي: انهيار ما بعد التوزيع (posterior collapse) من أكثر مشاكل VAE شيوعاً، ورتبة التغاير هي مقياسه الرسمي.

مثال (15-4.2): تحسين توزيع التضمينات (Isotropy)

المعطيات: 10,000 تضمين جملة؛ القيم المفردة العشر الأولى $(50,\ 10,\ 3,\ 2,\ 1.8,\ \dots) \Longrightarrow$ تباين مركّز جداً. المطلوب: قياس «التجانس الاتجاهي» (isotropy) وتحسينه.
الحل: الخطوة 1: مقياس التجانس $I = \frac{\sigma_{\min}}{\sigma_{\max}}$؛ هنا $I \approx 0.02 \Longrightarrow$ رديء. الخطوة 2: السبب: مركّبة هيمنة مشتركة بين كل الجمل (مثل طول الجملة أو تكرار كلمة شائعة). الخطوة 3: العلاج: نُطبّق غرام–شميدت لإزالة المركّبة المهيمنة الأولى: $z \leftarrow z - \langle z, u_1\rangle u_1$. الخطوة 4: بعد الإزالة: القيم المفردة $(10,\ 3,\ 2,\ \dots) \Longrightarrow I \approx 0.2 \Longrightarrow$ تحسّن $\times 10$.
النتيجة: تجانس $0.02 \longrightarrow 0.2$. الربط بالذكاء الاصطناعي: تقنية «إزالة المركّبة الرئيسية» (All-but-the-Top) حسّنت أداء تضمينات الجمل في معايير الاسترجاع الدلالي بشكل ملحوظ.

6.5.2 أخطاء شائعة

الخطأ	الصواب
استخدام غرام–شميدت الكلاسيكي في الفاصلة العائمة	استخدم النسخة المعدّلة أو Householder
افتراض Q مربّعة دائماً	Q مستطيلة $m \times n$ بـ $Q^\top Q = I_n$ فقط
تطبيق غرام–شميدت على متجهات تابعة	ينهار عند $w_j = \mathbf{0}$؛ افحص $\|w_j\|$
تفضيل المعادلات النظامية على QR	QR لا يربّع عدد الحالة $\Longrightarrow$ أدقّ

الأهمية: «كم بُعداً من المعلومات يمرّ فعلاً عبر هذه الطبقة؟» — سؤالٌ تجيب عنه الرتبة. وهي الأداة التي تكشف انهيار التمثيل، وتحدّد المعلمات الفعّالة، وتبرّر ضغط النماذج.

1.6.2 الصياغة الرسمية

النظرية الأساسية: لتكن $A : \mathbb{R}^n \to \mathbb{R}^m$ تحويلاً خطياً (أو مصفوفة $A \in \mathbb{R}^{m\times n}$):

$$\underbrace{\dim \ker(A)}_{\text{nullity العدمية}} + \underbrace{\dim \operatorname{im}(A)}_{\text{rank الرتبة}} = \dim \mathbb{R}^n = n \tag{28.2}$$

أي بصيغة مختصرة:

$$\operatorname{nullity}(A) + \operatorname{rank}(A) = n \tag{29.2}$$

حيث:

$$\ker(A) = \{x \in \mathbb{R}^n : Ax = \mathbf{0}\}, \qquad \operatorname{im}(A) = \{Ax : x \in \mathbb{R}^n\} = \operatorname{col}(A) \tag{30.2}$$

خصائص الرتبة الملازمة:

$$\operatorname{rank}(A) = \operatorname{rank}(A^\top) = \dim \operatorname{row}(A) = \dim \operatorname{col}(A) \tag{31.2}$$

$$\operatorname{rank}(A) \le \min(m, n), \qquad \operatorname{rank}(A^\top A) = \operatorname{rank}(AA^\top) = \operatorname{rank}(A) \tag{32.2}$$

متراجحة سيلفستر للرتبة:

$$\operatorname{rank}(A) + \operatorname{rank}(B) - n \le \operatorname{rank}(AB) \le \min\big(\operatorname{rank}(A), \operatorname{rank}(B)\big) \tag{33.2}$$

$$\operatorname{rank}(A + B) \le \operatorname{rank}(A) + \operatorname{rank}(B) \tag{34.2}$$

حالات النظام $Ax = b$:

$$\operatorname{rank}(A) = \operatorname{rank}([A \mid b]) = n \iff \text{حلّ وحيد} \tag{35.2}$$

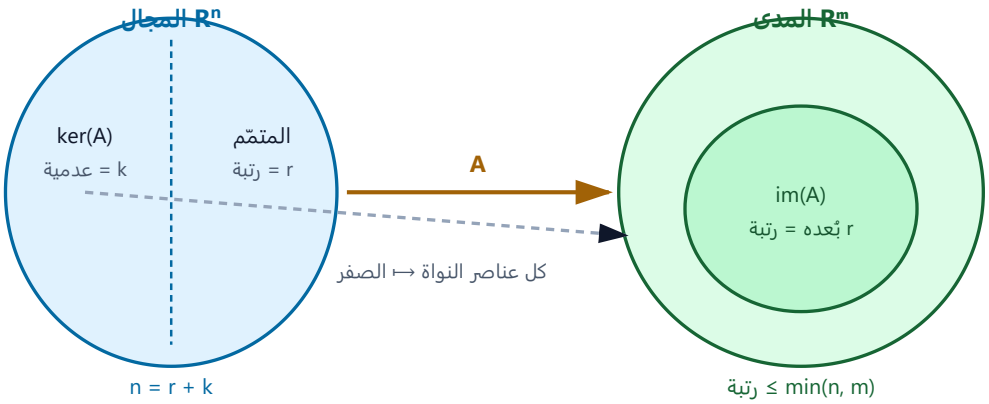
$$\operatorname{rank}(A) = \operatorname{rank}([A \mid b]) < n \iff \text{حلول لانهائية (ببعد } n - \operatorname{rank}(A)) \tag{36.2}$$

$$\operatorname{rank}(A) < \operatorname{rank}([A \mid b]) \iff \text{لا حلّ} \Rightarrow \text{نلجأ للمربعات الصغرى} \tag{37.2}$$

2.6.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
$\ker(A)$	النواة (فضاء العدم)	المدخلات التي تُصبح صفراً	ما «يُفقد» من المعلومات
$\operatorname{im}(A)$	الصورة (المدى)	كل المخرجات الممكنة	فضاء التمثيل
$\operatorname{rank}(A)$	الرتبة	عدد الأعمدة/الصفوف المستقلة	np.linalg.matrix_rank
$\operatorname{nullity}(A)$	العدمية	$n - \operatorname{rank}(A)$	درجات الحرية المفقودة
$\operatorname{col}(A)$	فضاء الأعمدة	توليده = الصورة	—
$\operatorname{row}(A)$	فضاء الصفوف	بُعده = الرتبة	(31.2)
$[A \mid b]$	المصفوفة المُلحَقة	A مع عمود b	فحص وجود الحلّ
n	بُعد المجال	عدد الميزات/المعلمات	—
m	بُعد المدى	عدد المخرجات	—
$\operatorname{rank}_\varepsilon$	الرتبة العددية	عدد القيم المفردة $> \varepsilon$	الرتبة العملية في الحاسوب

نظرية الرتبة والعدمية: dim ker(A) + dim im(A) = n



شكل (2.5): ما «يُفقد» في النواة يقابله بالضبط ما «يبقى» في الصورة

شكل ٥.٢: *
الرتبة والعدمية

3.6.2 الشكل الهندسي

شكل (5.2): المجال $\mathbb{R}^n$ ينقسم إلى نواة (بُعد k) ومتمّم (بُعد r)؛ والمتمّم يُنقل وفاءً إلى الصورة.

4.6.2 البرهان

ليكن $\{u_1, \dots, u_k\}$ أساساً لـ $\ker(A)$. نُكمّله (بلامّة التبادل 3.2 يمكن التكميل) إلى أساس للفضاء كله:

$$\mathcal{B} = \{u_1, \dots, u_k,\ v_1, \dots, v_r\}, \qquad k + r = n$$

ندّعي أن $\{Av_1, \dots, Av_r\}$ أساسٌ لـ $\operatorname{im}(A)$:

- **التوليد:** كل $y = Ax$ حيث $x = \sum \alpha_i u_i + \sum \beta_j v_j \Longrightarrow Ax = \sum \alpha_i \underbrace{Au_i}_{=0} + \sum \beta_j Av_j$ في $\operatorname{span}\{Av_j\}$.
- **الاستقلال:** لو $\sum \beta_j Av_j = 0$ فـ $A(\sum \beta_j v_j) = 0 \Longrightarrow \sum \beta_j v_j \in \ker(A)$ $\Longrightarrow$ هو تركيبة من $\{u_i\}$ $\Longrightarrow$ بالاستقلال كل $\beta_j = 0$.

إذن $\dim \operatorname{im}(A) = r$ و $\dim \ker(A) = k$ و $r + k = n$ $\Longrightarrow$ (28.2). $\blacksquare$

5.6.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (5.2-1): رتبة مصفوفة أوزان طبقة عصبية

المعطيات: طبقة بـ 256 مدخلاً و 128 مخرجاً، مصفوفة الأوزان $W \in \mathbb{R}^{128 \times 256}$، الرتبة المقاسة 90. المطلوب: كم خلية مخرجة «فعّالة»؟ وكم بُعداً من المدخل مهمل؟

الحل: الخطوة 1: $\operatorname{rank}(W) = 90 \implies$ فضاء المخرجات الفعّال بُعده 90 من 128. الخطوة 2: العدمية $= 256 - 166 = 90 \implies 166$ بُعداً من المدخل لا تؤثّر في المخرج. الخطوة 3: نسبة الهدر $166/256 = 64.8\%$.

النتيجة: 38 خلية مخرجة زائدة، و 166 بُعد مدخل مُهمَلة. الربط بالذكاء الاصطناعي: قياس الرتبة الفعّالة أداة تشخيص قوية: رتبة منخفضة $\implies$ إمكانية تقليم (pruning) الطبقة دون فقدان يُذكر.

مثال (2-5.2): LoRA وتحديد الرتبة

المعطيات: $W_0 \in \mathbb{R}^{4096\times 4096}$، التحديث $\Delta W = BA$ برتبة $r = 8$. المطلوب: بُعد صورة التحديث والعدمية.

الحل: الخطوة 1: $\operatorname{rank}(\Delta W) \le \min(\operatorname{rank} B,\ \operatorname{rank} A) \le 8$ بـ (33.2). الخطوة 2: صورة التحديث بُعدها ≤ 8 من أصل 4096. الخطوة 3: العدمية $4096 - 8 = 4088 \implies$ كل اتجاه خارج فضاء بُعده 8 يمرّ دون تغيير.

النتيجة: 99.8% من الاتجاهات «غير قابلة للتحديث» بهذه الطريقة. الربط بالذكاء الاصطناعي: هذا قيدٌ متعمَّد: الضبط الدقيق يحتاج مرونة محدودة لتجنّب النسيان الكارثي؛ ولذلك نجحت LoRA عملياً برتب 4–64 فقط.

مثال (3-5.2): أثر Dropout على الرتبة الفعّالة

المعطيات: مصفوفة تفعيلات $H \in \mathbb{R}^{512\times 128}$ (عيّنات × خلايا) برتبة 128، نُطبّق dropout بمعدل $p = 0.5$.

المطلوب: ما أثر ذلك على الرتبة؟

الحل: الخطوة 1: كل خلية تُصفَّر باحتمال 0.5 $\implies$ الرتبة المتوقّعة تنخفض لكن لا تصل إلى 64 بالضرورة. الخطوة 2: الرتبة بعد التصفير $\le \min(512،$ عدد الخلايا الناجية$) \approx 64$. الخطوة 3: لكن القياس التجريبي يظهر رتبة فعّالة أعلى ($\approx$ 90–110) لأن التصفير لا يخلق تبعية كاملة. الخطوة 4: المعنى: dropout يمنع الشبكة من الاعتماد على تركيبات خطية محدّدة $\implies$ تنظيم ضمني.

النتيجة: انخفاض الرتبة الفعّالة = تنظيم. الربط بالذكاء الاصطناعي: Dropout يمكن فهمه كـ «تنظيم على رتبة التمثيل»، وهو يمنع التخصّص المفرط لأعمدة محدّدة.

مثال (4-5.2): كشف الميزات المتكرّرة في جدول

المعطيات: مصفوفة ميزات $X \in \mathbb{R}^{1000\times 12}$، الرتبة المقاسة 10. المطلوب: كم علاقة خطية مخفية بين الميزات؟

الحل: الخطوة 1: العدمية $12 - 10 = 2 \implies$ بُعد فضاء العلاقات $= 2$. الخطوة 2: إذن توجد معادلتان خطيتان مستقلتان بين الأعمدة (مثل: «المساحة بالمتر^2 = 10.76 × المساحة بالقدم^2» و «المجموع = 1»). الخطوة 3: يجب إسقاط عمودين قبل الانحدار.

النتيجة: علاقتان خطيتان خفيتان يجب إزالتهما. الربط بالذكاء الاصطناعي: الرتبة العددية تُحسب بعدد القيم المفردة التي تتجاوز عتبة $\varepsilon = \sigma_1 \cdot 10^{-12}$، وهي طريقة عملية لاكتشاف التعدد الخطي تلقائياً.

مثال (2.5-5): عدد المعلمات القابلة للتحديد

المعطيات: انحدار خطي بـ $p = 200$ ميزة و $n = 150$ عيّنة. المطلوب: هل يمكن تحديد المعلمات الـ 200؟

الحل: الخطوة 1: $X \in \mathbb{R}^{150\times 200} \Rightarrow \text{rank}(X) \leq \min(150, 200) = 150$. الخطوة 2: العدمية $= 200 - 150 = 50$ فضاء حلول للمعادلات المتجانسة بُعده 50 على الأقل. الخطوة 3: إذن توجد عائلات لانهائية من الأوزان تعطي نفس المخرجات $\Rightarrow X^\top X$ منفردة.

النتيجة: غير قابلة للتحديد $\Rightarrow$ يلزم تنظيم Ridge ($X^\top X + \lambda I$ يجعلها قابلة للعكس). الربط بالذكاء الاصطناعي: إضافة λI ترفع كل القيم الذاتية بمقدار $\lambda \Rightarrow$ المصفوفة موجبة التحديد $\Rightarrow$ حلّ وحيد، وهذا هو التبرير الرياضي لتنظيم L_2.

مثال (2.5-6): انهيار الرتبة في الانتباه (Rank Collapse)

المعطيات: شبكة محوّل بـ $L = 24$ طبقة، مصفوفة الانتباه A صفوفها توزيعات احتمالية، نلاحظ أن مخرجات الطبقات تتقارب. المطلوب: تفسير ذلك بالرتبة.

الحل: الخطوة 1: التحديث المتبقّي: $X^{(\ell+1)} = X^{(\ell)} + AX^{(\ell)}W$. الخطوة 2: بدون التوصيل المتبقّي والتطبيع، تكرار ضرب المصفوفات ذات القيمة المفردة المهيمنة 1 يجعل A^L تتقارب إلى مصفوفة رتبتها 1. الخطوة 3: $\Rightarrow$ كل الرموز (tokens) تحصل على التمثيل ذاته $\Rightarrow$ انهيار الرتبة إلى 1. الخطوة 4: العلاج: التوصيلات المتبقّية تضيف I فتبقي القيم المفردة قريبة من 1 ولا تنهار.

النتيجة: الرتبة تنهار من d إلى 1 مع العمق. الربط بالذكاء الاصطناعي: ظاهرة collapse rank موثّقة نظرياً، وهي تفسّر لماذا المحوّلات العميقة جداً تحتاج تطبيعاً طبقياً وتوصيلات متبقّية لتعمل.

مثال (2.5-7): رتبة مصفوفة النواة (Kernel Matrix)

المعطيات: 500 عيّنة، نواة غاوسية $K_{ij} = \exp(-\|x_i - x_j\|^2/2\sigma^2)$ مع $\sigma = 0.1$. المطلوب: هل K قابلة للعكس؟ وماذا يعني ذلك؟

الحل: الخطوة 1: نظرياً K متماثلة موجبة التحديد $\Rightarrow$ رتبتها 500. الخطوة 2: عملياً القيم الذاتية تتلاشى أُسّياً $\Rightarrow$ الرتبة العددية (بعتبة 10^{-12}) قد تكون 60 فقط. الخطوة 3: $\Rightarrow$ عكس K غير مستقر $\Rightarrow$ نضيف تنظيم $K + \lambda I$ (كما في Ridge Kernel Regression).

النتيجة: رتبة عددية 60 من 500 $\Rightarrow$ تنظيم إلزامي. الربط بالذكاء الاصطناعي: انهيار طيف النواة هو سبب الحاجة إلى تنظيم في كل طرق النواة، وهو أيضاً ما يفسّر سلوك «النواة العصبية» (NTK) في الشبكات العريضة (الفصل 40).

مثال (2.5-8): رتبة مصفوفة البيانات وعدد العيّنات المطلوب

المعطيات: بيانات صور في $\mathbb{R}^{784}$، الرتبة المقاسة لمصفوفة العيّنات (10,000 عيّنة) هي 784. المطلوب: كم عيّنة نحتاج على الأقل لضمان رتبة كاملة؟

الحل: الخطوة 1: $\text{rank}(X) \leq \min(N, 784) \implies$ نحتاج $N \geq 784$. الخطوة 2: لكن الرتبة الكاملة عددية تتطلّب استقلالاً شبه تام $\implies$ عملياً $N \gg 784$. الخطوة 3: الرتبة 784 المحقّقة $\implies$ البيانات تملأ الفضاء المحيط (لا متعدّد منخفض البعد) $\implies$ قد يدلّ على ضجيج عالٍ.

النتيجة: 784 على الأقل، عملياً آلاف. الربط بالذكاء الاصطناعي: الرتبة أداة لتقدير البعد الجوهري لمتعدّد البيانات، إن كانت الرتبة $\approx$ البعد المحيط فالمتعدّد «ممتلئ» ولا فائدة من تقليل الأبعاد.

مثال (2.5-9): التضمين العواملي في التوصية (Matrix Factorization)

المعطيات: مصفوفة تفاعلات المستخدم-العنصر $R \in \mathbb{R}^{10^6 \times 10^5}$؛ نُقرّبها برتبة $k = 50$: $R \approx UV^\top$ مع $U \in \mathbb{R}^{10^6 \times 50}$. المطلوب: عدد المعلمات ونسبة الضغط.

الحل: الخطوة 1: المعلمات الأصلية (الافتراضية) $= 10^6 \times 10^5 = 10^{11}$. الخطوة 2: المعلمات بعد التحليل $= 50(10^6 + 10^5) = 5.5 \times 10^7$. الخطوة 3: النسبة $5.5 \times 10^7 / 10^{11} = 5.5 \times 10^{-4} \implies$ ضغط $\times 1818$. الخطوة 4: العدمية $10^5 - 50 =$ بالنسبة لفضاء العناصر.

النتيجة: ضغط بأكثر من 1800 مرة. الربط بالذكاء الاصطناعي: هذا هو جوهر أنظمة التوصية الكلاسيكية (Netflix Prize)، والفرضية: التفضيلات تتولّد من عدد قليل من «العوامل الكامنة» = رتبة منخفضة.

مثال (2.5-10): قياس أثر التقليم على رتبة الأوزان

المعطيات: طبقة $W \in \mathbb{R}^{1024 \times 1024}$، الرتبة قبل التقليم 900، بعد تقليم 80% من الأوزان الرتبة 780. المطلوب: تقييم الفقدان البنيوي.

الحل: الخطوة 1: فقدان الرتبة $= 900 - 780 = 120 \implies 13\%$ من سعة التمثيل. الخطوة 2: فقدان المعلمات $= 80\%$. الخطوة 3: الكفاءة: فقدنا 80% من الذاكرة مقابل 13% من الرتبة $\implies$ صفقة ممتازة. الخطوة 4: الحدّ: الرتبة بعد التقليم $\leq 780 \implies$ لا يمكن للنموذج أن يمثّل أكثر من 780 بُعداً مستقلاً.

النتيجة: مقايضة 80%↔13% ممتازة. الربط بالذكاء الاصطناعي: **درس:** التقليم يدمّر المعلمات أسرع بكثير مما يدمّر الرتبة، ولهذا تنجح طرق ضغط النماذج إلى هذا الحد.

مثال (2.5-11): عامل تضخّم التباين (VIF) لاكتشاف التبعية

المعطيات: ميزة x_j مفسَّرة بباقي الميزات بمعامل تحديد $R_j^2 = 0.98$. المطلوب: حساب VIF وتفسيره بالرتبة.

الحل: الخطوة 1: $\text{VIF}_j = \frac{1}{1-R_j^2} = \frac{1}{0.02} = 50$. الخطوة 2: $\text{VIF} > 10 \implies$ تعدد خطي شديد. الخطوة 3: التفسير بالرتبة: x_j قريبة من فضاء الأعمدة للباقي $\implies$ الرتبة العددية لـ X أقل من عدد الأعمدة.

النتيجة: تعدد خطي حادّ، يجب إسقاط الميزة أو دمجها. الربط بالذكاء الاصطناعي: VIF هو «مقياس بعد المسافة عن الفضاء الجزئي»، وهو تطبيق مباشر لمفهوم الاستقلال الخطي على تشخيص النماذج.

مثال (2.5.12): درجات الحرية الفعّالة في Ridge

المعطيات: انحدار Ridge على $X \in \mathbb{R}^{100\times 50}$، القيم الذاتية لـ $X^\top X$: $(100, 64, 25, \dots)$، $\lambda = 4$. المطلوب: حساب درجات الحرية الفعّالة.

الحل: الخطوة 1: مؤثّر القبعة $H_\lambda = X(X^\top X + \lambda I)^{-1}X^\top$. الخطوة 2: درجات الحرية $= \operatorname{tr}(H_\lambda) = \sum_i \frac{d_i}{d_i+\lambda}$ حيث d_i قيم $X^\top X$ الذاتية. الخطوة 3: للقيم المعطاة: $\frac{100}{104}+\frac{64}{68}+\frac{25}{29}+\cdots \approx 0.962+0.941+0.862+\cdots$. الخطوة 4: المجموع ≈ 40 (بدل 50 بدون تنظيم).

النتيجة: 40 درجة حرية فعّالة بدل 50. الربط بالذكاء الاصطناعي: $\operatorname{tr}(H_\lambda)$ هو مقياس «تعقيد النموذج الفعّال»؛ ويُستخدم في معايير AIC/BIC لاختيار النماذج.

مثال (2.5.13): معايرة كاميرا كحلّ نظام

المعطيات: معايرة كاميرا تعطي نظاماً $Ax = b$ بـ $A \in \mathbb{R}^{30\times 24}$ (30 معادلة من نقاط مرجعية، 24 معلمة مجهولة). المطلوب: هل الحلّ وحيد؟

الحل: الخطوة 1: نحتاج $\operatorname{rank}(A) = 24$ (= عدد المجهولات). الخطوة 2: $\operatorname{rank}(A) \le \min(30, 24) = 24$ $\Longrightarrow$ ممكن إن كانت النقاط في وضع عام. الخطوة 3: إن كانت كل النقاط على مستوٍ واحد $\Longrightarrow$ الرتبة تنخفض $\Longrightarrow$ عدمية > 0 $\Longrightarrow$ حلول لانهائية. الخطوة 4: عملياً نحلّ بالمربعات الصغرى عبر SVD لأن $\operatorname{rank}(A) < \operatorname{rank}([A \mid b])$ دائماً بسبب الضجيج (37.2).

النتيجة: الحلّ وحيد في الوضع العام، عملياً نستخدم المربعات الصغرى. الربط بالذكاء الاصطناعي: معايرة المستشعرات في الروبوتات والقيادة الذاتية كلها مسائل مربعات صغرى، ونظرية الرتبة تحدّد متى تكون المسألة «محدَّدة جيداً».

مثال (2.5.14): مصفوفة لابلاس وعدد المكوّنات المتصلة

المعطيات: رسم بياني بـ 100 عقدة، مصفوفة لابلاس $L = D - A$، الرتبة 97. المطلوب: كم مكوّناً متصلاً في الرسم؟

الحل: الخطوة 1: نظرية: $\dim\ker(L) =$ عدد المكوّنات المتصلة. الخطوة 2: العدمية $= 100 - 97 = 3$. الخطوة 3: $\Longrightarrow$ 3 مكوّنات متصلة. الخطوة 4: النواة مولّدة بمؤشّرات المكوّنات (متجهات ثابتة على كل مكوّن).

النتيجة: 3 مكوّنات متصلة. الربط بالذكاء الاصطناعي: هذه الحقيقة أساسية في الشبكات العصبية البيانية (GNN): الرتبة/العدمية تحدّد «التجاويف» وتُستخدم في التجميع الطيفي (spectral clustering) عبر القيم الذاتية الصغيرة.

مثال (2.5.15): قياس أثر التكميم على الرتبة الفعّالة

المعطيات: مصفوفة أوزان W برتبة عددية 100 (بعتبة 10^{-6})، بعد تكميم int8 تصبح الرتبة العددية 42. المطلوب:

تفسير وعلاج.

الحل: الخطوة 1: التكميم يضيف خطأً $\|E\|_F \approx 0.01\|W\|_F$. الخطوة 2: كل القيم المفردة التي كانت $\|E\|_2 <$ تُغرق في الضجيج $\Longrightarrow$ تختفي من الرتبة العددية. الخطوة 3: فقدنا 58 بُعداً تمثيلياً $\Longrightarrow$ انخفاض الدقة المتوقّع. الخطوة 4: العلاج: تكميم بوعي القيم المفردة (SVD-aware) أو per-channel quantization لتقليل $\|E\|$.

النتيجة: الرتبة الفعّالة مؤشر حسّاس لجودة التكميم. الربط بالذكاء الاصطناعي: هذا يفسّر لماذا تُحافظ طرق التكميم المتقدّمة (GPTQ, AWQ) على المكوّنات الطيفية المهيمنة: الرتبة الفعّالة أهم من متوسط الخطأ التربيعي.

6.6.2 أخطاء شائعة

الخطأ	الصواب
حساب الرتبة بالقيم الذاتية بدل المفردة للرتبة العددية	الرتبة العددية تحتاج قيماً مفردة (موجبة دائماً)
افتراض $\operatorname{rank}(AB) = \min(\operatorname{rank} A, \operatorname{rank} B)$	متراجحة فقط (33.2) ليست مساواة
تجاهل العتبة عند القياس الحاسوبي	الرتبة «الدقيقة» حسّاسة للضجيج؛ استخدم $\operatorname{rank}_\varepsilon$
ظنّ أن $A^\top A$ قابلة للعكس دائماً	قابلة للعكس $\Longleftrightarrow \operatorname{rank}(A) = n$

المستوى (أ) — تطبيق مباشر

١. بيّن أن $\{v_1, v_2\}$ بـ $v_1 = (1, 2)$، $v_2 = (2, 4)$ تابعة خطياً.

٢. أوجد بُعد $\operatorname{span}\{(1, 0, 0), (0, 1, 0), (1, 1, 0)\}$.

٣. احسب $\cos\theta$ بين $u = (1, 2, 3)$ و $v = (3, 2, 1)$، وتحقّق من (8.2).

٤. أوجد إسقاط $y = (3, 4)$ على $\operatorname{span}\{(1, 0)\}$.

٥. طبّق غرام–شميدت على $v_1 = (1, 1, 0)$، $v_2 = (1, 0, 1)$.

٦. احسب رتبة وعدمية $A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$.

٧. احسب إسقاط $y = (1, 1, 1)$ على المستوي $x_1 + x_2 + x_3 = 0$.

٨. أثبت أن $|\cos\theta| \le 1$ يتبع مباشرة من (8.2).

٩. بيّن أن $\operatorname{rank}(A^\top A) = \operatorname{rank}(A)$ باستخدام النواة.

١٠. حلّ نظام المربعات الصغرى: $A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}$، $y = (1, 2, 2)^\top$.

المستوى (ب) — تركيب

١. ليكن $U = \{(x, y, 0)\}$ و $W = \{(0, y, z)\}$ في $\mathbb{R}^3$؛ احسب $\dim(U + W)$ و $\dim(U \cap W)$ وتحقّق من (5.2).

٢. أثبت أن $\|u + v\|^2 + \|u - v\|^2 = 2\|u\|^2 + 2\|v\|^2$ (متطابقة متوازي الأضلاع).

٣. أثبت أن إسقاطاً متعامداً P يحقّق $P^2 = P$ و $P^\top = P$، والعكس صحيح.

٤. أثبت أن $I - P_W$ هو الإسقاط على $W^\perp$.

٥. بيّن أن أعمدة Q من تحليل QR تحقّق $Q^\top Q = I$ إذا كانت Q مستطيلة؛ متى تصبح $Q Q^\top = I$؟

٦. أثبت أن $\operatorname{rank}(A+B) \le \operatorname{rank}(A) + \operatorname{rank}(B)$.

٧. في $\mathbb{R}^d$، برهن أن أقصى عدد متجهات بزاوية زوجية $\ge 60^\circ$ هو 2^d تقريباً (استخدم كوشي–شفارتس).

٨. أثبت أن $\|P_W y\| \le \|y\|$ (الإسقاط لا يكبّر).

٩. ليكن $A \in \mathbb{R}^{m \times n}$ بـ $m < n$؛ برهن أن $Ax = 0$ له حلٌّ غير صفري، وفسّر ذلك في سياق «المعلمات الزائدة».

١٠. أوجد أفضل تقريب من الدرجة الأولى للنقاط $(0,1), (1,0), (2,2)$ باستخدام الإسقاط.

المستوى (ج) — تحدٍّ

١. أثبت متراجحة بيسل (20.2) ثم متطابقة بارسيفال باستخدام نظرية الإسقاط.

٢. برهن مبرهنة Johnson–Lindenstrauss في صيغتها الأساسية باستخدام كوشي–شفارتس على الإسقاط العشوائي.

٣. أثبت أن $\operatorname{rank}(A) = \operatorname{rank}(A^\top A)$ باستخدام $\ker(A^\top A) = \ker(A)$.

٤. ليكن W مصفوفة أوزان متعامدة ($W^\top W = I$)؛ أثبت أن التدرّج على W في الشبكة العميقة يحفظ الناظم.

٥. برهن أن أفضل تقريب منخفض الرتبة لمصفوفة يُعطى باقتطاع SVD (مبرهنة Eckart–Young — مخطط البرهان فقط (يُفصَّل في الفصل 4).

٦. أثبت أن تقارب خوارزمية QR للقيم الذاتية يحفظ الطيف (مشابهة).

٧. بيّن أن فضاء متعددات الحدود من الدرجة $\le k$ على $[0,1]$ فضاءٌ متجهي بُعده $k+1$، وابحث أساساً متعامداً (متعددات ليجاندر).

٨. برهن أن $\dim \operatorname{span} \le$ عدد المتجهات، وأن التساوي $\iff$ الاستقلال.

٩. في شبكة بـ L طبقة وروابط متبقّية: برهن أن مسار التدرّج يمرّ عبر فضاء بُعده $\ge \dim \operatorname{im}(\prod J_\ell)$، وناقش أثر ذلك على التلاشي.

١٠. صمّم مقياساً عملياً لـ «الرتبة الفعّالة» لمصفوفة تمثيلات في شبكة عصبية، وبرر اختيار العتبة ε باستخدام تحليل الضجيج.

إجابات مختصرة

#	الإجابة
1	$v_2 = 2v_1$
2	2 (الثالث = مجموع الأولين)
3	$\langle u, v\rangle = 10$، $\|u\| = \|v\| = \sqrt{14} \Rightarrow \cos\theta = 10/14 = 0.714$
4	$(3, 0)$
5	$u_1 = \frac{1}{\sqrt{2}}(1,1,0)$، $w_2 = v_2 - \frac{1}{2}v_1$... بعد الحساب: $u_2 = \frac{1}{\sqrt{6}}(1,-1,2)$
6	رتبة 1، عدمية 1
7	$\hat{y} = y - \frac{y^\top \mathbf{1}}{3}\mathbf{1} = (0,0,0)$
8	بالتعريف (9.2) مع (8.2)
9	(29.2) $\Rightarrow$ نفس العدمية $\Rightarrow \ker(A^\top A) = \ker(A)$
10	$\beta = (2/3,\ 1/2)$
11	✓ $2 + 2 - 1 = 3 \Rightarrow \dim(U \cap W) = 1$، $\dim(U + W) = 3$
12	بسط الجداءات الداخلية
13	من (18.2)
14	تحقق شرط التعامد (14.2)
15	إذا كانت Q مربّعة $(m = n)$
16	$\operatorname{col}(A + B) \subseteq \operatorname{col}(A) + \operatorname{col}(B)$ مع (5.2)
17	بحجّة حجم الكرات على الكرة
18	بفيثاغورس (19.2)
19	$= n - \text{rank} \geq n - m > 0$ عدمية
20	$\hat{y} = 0.5 + 0.5t$
21	الإسقاط على $\operatorname{span}\{u_1, \ldots, u_k\}$ ثم فيثاغورس
22	تركيز القيم المفردة للإسقاط العشوائي
23	$x^\top A^\top A x = \|Ax\|^2 = 0 \iff Ax = 0$
24	$\|Qg\| = \|g\|$
25	بواسطة متراجحة Weyl للقيم المفردة
26	متشابهة $\Rightarrow S_{k+1} = Q_k^\top S_k Q_k$
27	أساس؛ ليجاندر بالتعامد على $[0,1]$ $\{1, t, \ldots, t^k\}$
28	مباشر من تعريف التوليد والاستقلال
29	رتبة جداء اليعقوبيات تحدّد «عرض عنق الزجاجة»
30	$\varepsilon = c \cdot \sigma_1 \cdot \sqrt{\text{تباين الضجيج}}$

النظرية	الصيغة المحورية	متى تستخدمها
شتاينيتز/ثبات البُعد	$\|\mathcal{B}_1\| = \|\mathcal{B}_2\| = \dim V$، $k \leq m$	حساب أبعاد الفضاءات واتحادها وتقاطعها
كوشي–شفارتس/المثلث	$\|\langle u, v\rangle\| \leq \|u\|\|v\|$	حدود التشابه، ليبشيتز، استقرار التدرّج
الإسقاط المتعامد	$\hat{y} = A(A^\top A)^{-1}A^\top y$	الانحدار، PCA، الضغط، إزالة التحيز
غرام–شميدت/QR	$A = QR$، $Q^\top Q = I$	تبييض، تهيئة متعامدة، حلول مستقرة
الرتبة والعدمية	$\text{rank} + \text{nullity} = n$	تشخيص انهيار التمثيل، المعلمات الفعّالة

الخيط الناظم: كل نظرية في هذا الفصل تجيب عن سؤال واحد: **كم بُعداً من المعلومات يمرّ فعلاً، وأين يذهب الباقي؟** — الإجابة تحدّد سعة النموذج واستقراره وقابليته للضغط.

الرمز	المعنى	القسم
V, $\mathbb{F}$, $\mathbf{0}$, $-v$	فضاء متجهي، حقل، صفر، معاكس جمعي	1.2
span, $\leq$, $\oplus$, dim	توليد، فضاء جزئي، جمع مباشر، بُعد	1.2
$\langle u, v\rangle$, $\|u\|$, θ	جداء داخلي، ناظم، زاوية	3.2
$\cos\theta$, $\perp$, $\hat{y}$, e	تشابه، تعامد، إسقاط، باقي	4.2–3.2
P_W, $A^\top A$, $x^\star$	مؤثّر إسقاط، مصفوفة غرام، حلّ أمثل	4.2
w_j, u_j, Q, R	متبقٍّ غرام–شميدت، متعامد معياري، عاملان	5.2
ker, im, rank, nullity	نواة، صورة، رتبة، عدمية	6.2
$\|A\|_{\text{op}}$, $\|A\|_F$, σ_1	ناظم تشغيلي، فروبنيوس، قيمة مفردة عليا	3.2
$\kappa_2(A)$, rank_ε	عدد الحالة، رتبة عددية	6.2–5.2
col, row, $[A \mid b]$	فضاء أعمدة، صفوف، مصفوفة مُلحَقة	6.2

١. **Strang** — *Introduction to Linear Algebra*, 4th ed., Ch. 1–4 (الفضاءات المتجهة، الإسقاط، التحليلات).

٢. **Axler** — *Linear Algebra Done Right*, 3rd ed., Ch. 1–6 (بُنى الفضاءات والتعامد بلا محدّدات).

٣. **Bau & Trefethen** — *Algebra Linear Numerical*, Lecture 7–11 (QR، SVD، الاستقرار العددي).

٤. **Loan Van & Golub** — *Computations Matrix* (المرجع الأمّ للحسابات الماتريسية).

٥. **Courville Bengio, Goodfellow,** — *Learning Deep*, Ch. 2 (الجبر الخطي التطبيقي للتعلّم العميق).

٦. **Bolukbasi et al. (2016)** — *Man is to Computer Programmer as Woman is to Homemaker?* تطبيق الإسقاط على إزالة التحيز *Embeddings Word Debiasing*.

الفصل القادم: المصفوفات والتحويلات الخطية — حيث تتحول الأوزان إلى «حركات هندسية» ونتعلّم قراءة ما تفعله كل طبقة بالبيانات.

المصفوفات والتحويلات الخطية

الشعار: «المصفوفة ليست جدول أرقام؛ إنها **حركة**. والطبقة العصبية ليست مجموعة أوزان؛ إنها تحويلٌ هندسي متبوعٌ بانثناء. افهم الحركة تفهم النموذج.»

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. تمثيل أي تحويل خطي بمصفوفة، وتغيير الأساس بكفاءة.

٢. استخدام **المحدّد** كمقياس لتضخّم الحجم ولاختبار قابلية العكس، وفهم دوره في النماذج التوليدية.

٣. استخدام **الآثر** ودوريّته لتبسيط حسابات الخسائر والتدرّجات الماتريسية.

٤. تطبيق **متطابقة وودبري** لتحديث المعكوسات بتحديثات منخفضة الرتبة (GP، RLS، كالمان).

٥. تفكيك أي تحويل خطي بـ **التفكك القطبي** إلى «شكل» (تدوير) و«حجم» (تمدد).

المتطلبات المسبقة

الفصلان الأول والثاني (المنطق والمجموعات · الفضاءات المتجهة والإسقاط).

خريطة الفصل

القسم	النظرية/القانون	عدد الأمثلة المحلولة
1.3	التمثيل الماتريسي للتحويل الخطي وتغيير الأساس	15
2.3	**نظرية المحدّد وخصائصه**	15
3.3	**نظرية الآثر ودوريّته**	15
4.3	**المعكوس ومتطابقة وودبري**	15
5.3	**التفكك القطبي والتصنيف الهندسي**	15
6.3	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

· Jacobian · Determinant · Similarity · Basis of Change · Representation Matrix · Map Linear · Inversion Block · Sherman–Morrison–Woodbury · Inverse Matrix · Property Cyclic · Trace · Product Kronecker · Factor Semidefinite Positive · Factor Orthogonal · Decomposition Polar Vectorization

1.1.3 الصياغة الرسمية

التحويل الخطي: دالة $T : V \to W$ تحفظ التركيبات الخطية:

$$T(\alpha u + \beta v) \;=\; \alpha\, T(u) \;+\; \beta\, T(v) \tag{1.3}$$

التمثيل الماتريسي: ليكن $\mathcal{B} = \{b_1, \ldots, b_n\}$ أساساً لـ V و $\mathcal{C}$ أساساً لـ W. تُعرَّف مصفوفة التحويل:

$$A \;=\; [T]_{\mathcal{C} \leftarrow \mathcal{B}}, \qquad A_{:,\,j} \;=\; [\,T(b_j)\,]_{\mathcal{C}} \tag{2.3}$$

أي: **العمود j من A هو صورة المتجه الأساس b_j مكتوبةً في أساس المدى.**
قاعدة العمل:

$$[\,T(v)\,]_{\mathcal{C}} \;=\; A\,[\,v\,]_{\mathcal{B}} \tag{3.3}$$

التركيب = ضرب المصفوفات:

$$[\,S \circ T\,] \;=\; [S]\,[T], \qquad (S \circ T)(v) = S(T(v)) \tag{4.3}$$

تغيير الأساس: إذا كان P مصفوفة تغيير أساس المجال و Q مصفوفة تغيير أساس المدى:

$$A' \;=\; Q^{-1}\,A\,P \tag{5.3}$$

حالة الخاصة — التمثيل الذاتي (المؤثّر الخطي $T : V \to V$):

$$A' \;=\; P^{-1}AP \tag{6.3}$$

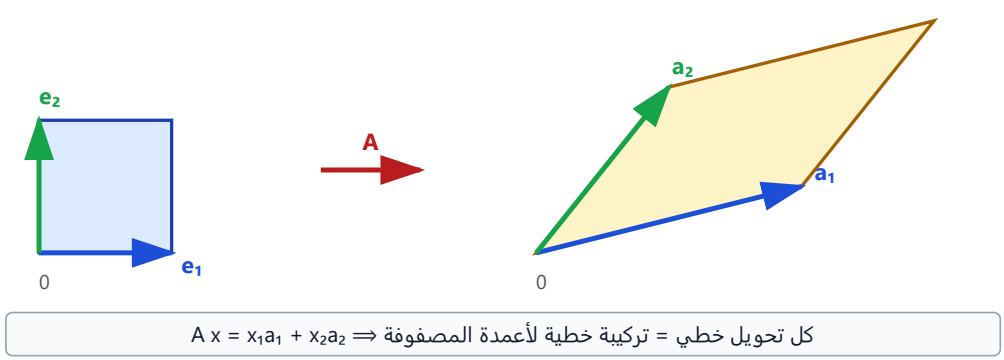
وهذا ما يُسمّى **التشابه** ؛(similarity) والمصفوفتان المتشابهتان لهما نفسه الطيف (نراه في الفصل 4).
أداتان ماتريسيتان ملازمتان:

$$\mathrm{vec}(ABC) \;=\; (C^{\top} \otimes A)\;\mathrm{vec}(B) \tag{7.3}$$

$$(A \otimes B)(C \otimes D) \;=\; (AC) \otimes (BD) \tag{8.3}$$

2.1.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة تطبيقية
T	تحويل خطي	دالة تحفظ الجمع والضرب القياسي	طبقة، التفاف، دوران
$\mathcal{B},\ \mathcal{C}$	أساسان	للمجال وللمدى	نظاما إحداثيات
$[v]_{\mathcal{B}}$	متجه الإحداثيات	إحداثيات v في الأساس $\mathcal{B}$	«التمثيل»
$A_{:,\,j}$	العمود j	صورة المتجه الأساس j	اقرأ الأعمدة لا الصفوف
$P,\ Q$	مصفوفة تغيير أساس	قابلة للعكس دائماً	أعمدتها = الأساس الجديد
$S \circ T$	التركيب	تطبيق T ثم S	ترتيب الضرب **معكوس**
A'	المصفوفة في الأساس الجديد	$Q^{-1}AP$	نفس التحويل، إحداثيات أخرى
$\otimes$	جداء كرونكر	مصفوفة كتلية $(mp) \times (nq)$	np.kron
vec	المتجهة	رصّ الأعمدة تحت بعضها	تحويل مصفوفة لمتجه
im, ker	الصورة والنواة	للتحويل = لأعمدة المصفوفة	الفصل 2



شكل ١.٣: *
المصفوفة كتحويل خطي

3.1.3 الشكل الهندسي

شكل (1.3): التحويل يرسل مربع الوحدة إلى متوازي أضلاع مولَّد بعمودَي المصفوفة. كل ما تحتاج معرفته عن التحويل موجود في أعمدته.

4.1.3 البرهان

الخطوة 1 — أن (3.3) صحيحة: ليكن $v = \sum_j x_j b_j$ أي $[v]_{\mathcal{B}} = x$. بالخطية (1.3):

$$T(v) \;=\; T\left(\sum_j x_j b_j\right) \;=\; \sum_j x_j\, T(b_j)$$

وبأخذ الإحداثيات في $\mathcal{C}$ (وهي عملية خطية أيضاً):

$$[T(v)]_{\mathcal{C}} \;=\; \sum_j x_j\, [T(b_j)]_{\mathcal{C}} \;=\; \sum_j x_j\, A_{:,j} \;=\; A\,x \;=\; A\,[v]_{\mathcal{B}}$$

الخطوة 2 — الوحدانية: لو وُجدت A_1, A_2 تحقّقان (3.3) لكل v، فبتطبيقها على المتجهات الأساس b_j (إحداثياتها e_j): $A_1 e_j = A_2 e_j$ لكل j ⟹ العمودان متساويان ⟹ $A_1 = A_2$.

الخطوة 3 — التركيب (4.3):

$$[S \circ T]\,[v]_{\mathcal{B}} = [S(Tv)] = [S]\,[Tv] = [S][T]\,[v]_{\mathcal{B}}$$

لكل v ⟹ $[S \circ T] = [S][T]$ بالوحدانية. ■

الخطوة 4 — تغيير الأساس: بما أن $[v]_{\mathcal{B}} = P\,[v]_{\mathcal{B}'}$ و $[w]_{\mathcal{C}'} = Q^{-1}[w]_{\mathcal{C}}$، نعوّض في (3.3):

$$[T(v)]_{\mathcal{C}'} = Q^{-1}[T(v)]_{\mathcal{C}} = Q^{-1}A[v]_{\mathcal{B}} = Q^{-1}AP[v]_{\mathcal{B}'} \;\Longrightarrow\; A' = Q^{-1}AP$$

5.1.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (3.1-1): مصفوفة الدوران بدل حلقة على البكسلات

المعطيات: تدوير صورة بزاوية $\theta = 30^\circ$ عكس عقارب الساعة. المطلوب: مصفوفة التحويل وإحداثيات نقطة $(1, 0)$ بعد الدوران.

الحل: الخطوة 1: صورة المتجه الأساس $e_1 = (1, 0)$ هي $(\cos 30^\circ, \sin 30^\circ) = (0.866,\ 0.5)$ $\Longrightarrow$ العمود الأول. الخطوة 2: صورة $e_2 = (0, 1)$ هي $(-\sin 30^\circ, \cos 30^\circ) = (-0.5,\ 0.866)$ $\Longrightarrow$ العمود الثاني. الخطوة 3: $R = \begin{bmatrix} 0.866 & -0.5 \\ 0.5 & 0.866 \end{bmatrix}$. الخطوة 4: $R\,(1,0)^\top = (0.866,\ 0.5)^\top$ ✓.

النتيجة: نقطة $(1, 0)$ تنتقل إلى $(0.866, 0.5)$. الربط بالذكاء الاصطناعي: كل زيادة بيانات (augmentation) هندسية هي ضرب بمصفوفة؛ وتنفيذها كـ «ضرب ماتريسي واحد» على دفعة كاملة أسرع بمرتبة من حلقة بكسلية على GPU.

مثال (3.1-2): الطبقة الكاملة الاتصال كتحويل أفّين

المعطيات: طبقة $z = Wx + b$ مع $W \in \mathbb{R}^{128\times 256}$، $x \in \mathbb{R}^{256}$. المطلوب: هل هذا تحويل خطي؟

الحل: الخطوة 1: اختبر (3.1): $T(\alpha x_1+\beta x_2) = W(\alpha x_1+\beta x_2)+b = \alpha W x_1+\beta W x_2+b$. الخطوة 2: لكن $\alpha T(x_1)+\beta T(x_2) = \alpha W x_1+\alpha b+\beta W x_2+\beta b$. الخطوة 3: الفرق $= b-(\alpha+\beta)b \neq 0$ $\Longrightarrow$ **ليس** خطياً بل **أفّين**. الخطوة 4: الحيلة: نُثبّت الإحداثي: $\tilde{x} = (x, 1)$ و $\tilde{W} = [W \mid b]$ $\Longrightarrow$ $\tilde{W}\tilde{x}$ تحويل خطي في $\mathbb{R}^{257}$.

النتيجة: أفّين في $\mathbb{R}^{256}$، خطي في $\mathbb{R}^{257}$. الربط بالذكاء الاصطناعي: «خدعة الإحداثي المتجانس» هي نفسها المستخدمة في الرسوم الحاسوبية (4×4 matrices)؛ وتجعل كل حسابات الطبقات خطية خالصة فيُبسَّط التفاضل.

مثال (3.1-3): im2col — الالتفاف كمصفوفة

المعطيات: التفاف 3×3 على مدخل 32×32 بقناة واحدة، نريد 16 مرشحاً. المطلوب: تحويل الالتفاف إلى ضرب ماتريسي واحد.

الحل: الخطوة 1: عدد المواضع المكانية للمخرج $= 30 \times 30 = 900$. الخطوة 2: نُعيد ترتيب كل رقعة 3×3 كعمود طوله 9 $\Longrightarrow$ مصفوفة المدخلات الموسّعة $\tilde{X} \in \mathbb{R}^{9\times 900}$. الخطوة 3: نرصّ المرشحات في $F \in \mathbb{R}^{16\times 9}$. الخطوة 4: المخرج $= F\tilde{X} \in \mathbb{R}^{16\times 900}$ $\Longrightarrow$ ضرب ماتريسي واحد (GEMM).

النتيجة: الالتفاف = GEMM على مصفوفة 9×16 بـ 900×9. الربط بالذكاء الاصطناعي: هذا بالضبط ما تفعله cuDNN: تحويل الالتفاف إلى ضرب ماتريسي لأن الـ GPU مُحسَّن جداً على GEMM؛ ومنه تأتي سرعة التدريب الحديثة.

مثال (3.1-4): PCA كتغيير أساس

المعطيات: بيانات في $\mathbb{R}^{50}$؛ مصفوفة المركبات $U \in \mathbb{R}^{50\times 10}$ (أعمدة متعامدة معيارية). المطلوب: صيغة الإسقاط على فضاء المركبات، وصيغة العودة للفضاء الأصلي.

الحل: الخطوة 1: الإحداثيات في الأساس الجديد: $z = U^\top x \in \mathbb{R}^{10}$. الخطوة 2: العودة (إعادة الإعمار): $\hat{x} = Uz$. الخطوة 3: المؤثّر الكامل: $\hat{x} = UU^\top x \implies$ وهو الإسقاط P_W من الفصل 2. الخطوة 4: هنا $P = U$ (من الأساس الأصلي للجديد) و $Q = U$ للمدى، وبما أن $U^\top U = I$ فـ $Q^{-1} = U^\top$.

النتيجة: $z = U^\top x$ و $\hat{x} = Uz$. الربط بالذكاء الاصطناعي: كل تقليل أبعاد هو **تغيير أساس متبوع باقتطاع**؛ وفهم ذلك يجعل الـ PCA و autoencoder و تضمينات الكلمات كلها حالة واحدة من (5.3).

مثال (3.1-5): جدول البحث في طبقة التضمين كمصفوفة متناثرة

المعطيات: مفردات $|V| = 50{,}000$؛ بُعد التضمين $d = 256$؛ المدخل one-hot $x \in \{0,1\}^{50000}$. المطلوب: التعبير عن البحث كضرب ماتريسي وعدد العمليات.

الحل: الخطوة 1: $E \in \mathbb{R}^{256\times 50000}$ مصفوفة التضمين؛ $e = Ex$. الخطوة 2: لأن x متجه one-hot، فالناتج هو العمود i من E فقط. الخطوة 3: عدد العمليات نظرياً $256 \times 50000 = 1.28 \times 10^7$، لكن فعلياً نسخة واحدة بحجم 256. الخطوة 4: $\implies$ التضمين «خطي» رسمياً لكن تنفيذه تحسينٌ للتناثر.

النتيجة: عملية بحث $O(1)$ لا $O(|V| \cdot d)$. الربط بالذكاء الاصطناعي: فهم طبقة التضمين كتحويل خطي يبرّر ربطها بالطبقة التالية (weight tying) في نماذج اللغة: مصفوفة فكّ الترميز = $E^\top$).

مثال (3.1-6): تحويل فضاء اللون RGB $\longrightarrow$ YUV

المعطيات: تحويل قياسي: $Y = 0.299R + 0.587G + 0.114B$؛ $U = 0.492(B - Y)$؛ $V = 0.877(R - Y)$. المطلوب: مصفوفة التحويل $M \in \mathbb{R}^{3\times 3}$.

الحل: الخطوة 1: نُعيد كتابة U: $-0.147R - 0.289G + 0.436B$ = $0.615R - 0.515G - 0.100B$. الخطوة 2: و V: $= 0.615R - 0.515G - 0.100B$. الخطوة 3: إذن $M = \begin{bmatrix} 0.299 & 0.587 & 0.114 \\ -0.147 & -0.289 & 0.436 \\ 0.615 & -0.515 & -0.100 \end{bmatrix}$. الخطوة 4: كل بكسل: $(Y,U,V)^\top = M(R,G,B)^\top$.

النتيجة: تحويل خطي واحد لكل الصورة دفعةً واحدة. الربط بالذكاء الاصطناعي: التحويلات الخطية على مستوى البكسل تُدمَج في الطبقة الأولى من الشبكة (أو تُطبَّق مسبقاً في خط المعالجة) دون تكلفة إضافية تُذكر.

مثال (3.1-7): التوسيط (Centering) تحويلٌ أفّين

المعطيات: دفعة $X \in \mathbb{R}^{1000\times 64}$، المتوسط $\mu \in \mathbb{R}^{64}$. المطلوب: صيغة التوسيط كمصفوفة.

الحل: الخطوة 1: $X_c = X - \mathbf{1}\mu^\top$. الخطوة 2: بالمصفوفة المركزية $H_c = I - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$: $X_c = H_c X$. الخطوة 3: H_c مؤثّر إسقاط ($H_c^2 = H_c$، $H_c^\top = H_c$) $\implies$ يزيل مركّبة المتوسط. الخطوة 4: و $\operatorname{rank}(H_c) = n - 1$ $\implies$ درجة حرية واحدة تُفقد (المتوسط).

النتيجة: الوسيط = إسقاط بمصفوفة مركزية. الربط بالذكاء الاصطناعي: H_c يظهر في صيغة التغاير: $\Sigma = \frac{1}{n-1}X_c^\top X_c = \frac{1}{n-1}X^\top H_c X$؛ وهي صيغة تُحسب دون تشكيل X_c صراحةً.

مثال (3.1-8): one-hot ⟶ تضمين في المحوّلات

المعطيات: تضمينات الرموز $E \in \mathbb{R}^{d\times|V|}$؛ ترميز موضعي $P \in \mathbb{R}^{d\times L}$. المطلوب: صيغة المدخل الكامل للمحوّل لسياق طوله L.

الحل: الخطوة 1: لكل موضع t: $x_t = E\,o_t + P\,p_t$ حيث o_t one-hot للكلمة و p_t one-hot للموضع. الخطوة 2: بالرصّ: $X = EO + PP_{\text{pos}}$ مع $O \in \mathbb{R}^{|V|\times L}$. الخطوة 3: عدد المعلمات: $|V|d + Ld$. الخطوة 4: عملياً يُخزَّن كجدولَي بحث ويُضافان $\Longrightarrow O(Ld)$.

النتيجة: مدخل المحوّل = مجموع تحويلين خطيين. الربط بالذكاء الاصطناعي: هذا يوضّح لماذا الترميز الموضعي المطلق لا يتوسّع لسياقات أطول من L المدرَّبة $\Longrightarrow$ ومنه ظهر الترميز النسبي (RoPE).

مثال (3.1-9): مصفوفة الكاميرا الخارجية (Extrinsic)

المعطيات: نقطة في إحداثيات العالم $X_w \in \mathbb{R}^3$؛ الكاميرا بدوران R وانزياح t. المطلوب: الإحداثيات في نظام الكاميرا.

الحل: الخطوة 1: $X_c = R\,X_w + t$. الخطوة 2: بالصيغة المتجانسة: $\tilde{X}_c = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix}\tilde{X}_w$ مع $\tilde{X} = (X, 1)$. الخطوة 3: المصفوفة 4×4 قابلة للعكس (لأن R متعامدة بـ $\det = \pm 1$). الخطوة 4: العكس: $\tilde{X}_w = \begin{bmatrix} R^\top & -R^\top t \\ 0 & 1 \end{bmatrix}\tilde{X}_c$ توفير كبير: $R^{-1} = R^\top \Longrightarrow$.

النتيجة: تحويل متجانس واحد، وعكسه مجّاني (مقلوب الدوران). الربط بالذكاء الاصطناعي: المصفوفات المتعامدة تجعل العكس = المنقول $\Longrightarrow$ وهذا سبب شيوعها في كل طبقات الذكاء الاصطناعي (دوران، RoPE تهيئة متعامدة، انعكاسات Householder).

مثال (3.1-10): RoPE — الترميز الموضعي الدوراني

المعطيات: بُعد التضمين d، نُعامل كل زوج (x_{2i}, x_{2i+1}) كمتجه في $\mathbb{R}^2$ وندوّره بزاوية $t\theta_i$. المطلوب: صيغة المصفوفة وسبب اختيار التدوير.

الحل: الخطوة 1: لكل زوج: $R(t\theta_i) = \begin{bmatrix} \cos t\theta_i & -\sin t\theta_i \\ \sin t\theta_i & \cos t\theta_i \end{bmatrix}$. الخطوة 2: المصفوفة الكلية $R_{\Theta,t}$ قطرية كتلية بحجم $d \times d$. الخطوة 3: الخاصية الحاسمة: $R(t_2 - t_1) = R(t_1)^\top R(t_2)$ $\Longrightarrow$ الجداء الداخلي يعتمد على **المسافة النسبية** فقط. الخطوة 4: وبما أن R متعامدة: $\|Rx\| = \|x\|$ $\Longrightarrow$ لا تغيّر أطوال التضمينات.

النتيجة: ترميز موضعي نسبي يحفظ الناظم. الربط بالذكاء الاصطناعي: RoPE هو الترميز الموضعي في LLaMA و GPT-NeoX و Mistral، وميزته الرياضية (التعامد + النسبية) هي بالضبط خاصية المصفوفات المتعامدة.

مثال (3.1-11): تقسيم الرؤوس في الانتباه متعدد الرؤوس

المعطيات: $d_{model} = 768$، عدد الرؤوس $h = 12 \Longrightarrow d_{head} = 64$. المطلوب: تعبير إعادة التشكيل كمصفوفة تبديل (permutation).

الحل: الخطوة 1: نُشكّل $Q \in \mathbb{R}^{L\times 768}$. الخطوة 2: نعيد التشكيل إلى $(L,\ 12,\ 64)$ ثم نبدّل إلى $(12,\ L,\ 64)$. الخطوة 3: رياضياً: تبديل أعمدة = ضرب بمصفوفة تبديل Π (متعامدة، $\Pi^{-1} = \Pi^{\top}$). الخطوة 4: إعادة التشكيل لا يغيّر القيم $\Longrightarrow$ «تغيير أساس» حرفياً على فضاء الميزات.

النتيجة: الانتباه متعدد الرؤوس = تغيير أساس كلي قطري. الربط بالذكاء الاصطناعي: هذا التفسير يجعل «عدد الرؤوس» خياراً لتقسيم فضاء التمثيل إلى فضاءات جزئية مستقلة — أي اختيار أساس مقسَّم.

مثال (3.1-12): معايرة درجات الحرارة (Temperature Scaling)

المعطيات: logits $z \in \mathbb{R}^C$، معامل حرارة $T > 0$. المطلوب: أثر التحويل $z \mapsto z/T$ على softmax.

الحل: الخطوة 1: $p_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$. الخطوة 2: التحويل $z \mapsto z/T$ خطي بمصفوفة $\frac{1}{T}I \Longrightarrow$ قياس متجانس. الخطوة 3: عند $T \to \infty$: $p \to$ توزيع منتظم (إنتروبيا قصوى). الخطوة 4: عند $T \to 0$: $p \to$ one-hot $\Longrightarrow$ واثق جداً.

النتيجة: T يتحكم بـ «حدة» التوزيع دون تغيير الترتيب. الربط بالذكاء الاصطناعي: المعايرة الاحتمالية (calibration) لشبكة مدموجة (distilled) أو مكمَّمة تُنجز بتعلّم T وحيد على مجموعة تحقّق $\Longrightarrow$ أرخص علاج للثقة المفرطة.

مثال (3.1-13): MFCC وتحويل DCT

المعطيات: طيف لوغاريتمي $s \in \mathbb{R}^{40}$ (من بنوك مرشّحات ميل)؛ نُطبّق DCT-II ونُبقي 13 معاملاً. المطلوب: صيغة التحويل الماتريسية وسبب استخدامه.

الحل: الخطوة 1: عناصر المصفوفة: $D_{ki} = \cos\left(\frac{\pi k(2i+1)}{2N}\right)$، $k = 0..12$، $N = 40$. الخطوة 2: $c = Ds$ مع $D \in \mathbb{R}^{13\times 40} \Longrightarrow$ تحويل خطي يضغط. الخطوة 3: صفوف D متعامدة (تقريباً) $\Longrightarrow$ إزالة ارتباط المعاملات. الخطوة 4: الاقتطاع إلى 13 $\Longrightarrow$ إسقاط على فضاء جزئي (الفصل 2).

النتيجة: $40 \longrightarrow 13$ مع إزالة الارتباط. الربط بالذكاء الاصطناعي: DCT هو «الـ PCA المسبق الصنع»؛ ونفس الفكرة تظهر في ضغط الصور (JPEG) وفي تحويل الميزات قبل الشبكات الخفيفة.

مثال (3.1-14): التبييض كتغيير أساس متبوع بقياس

المعطيات: ميزات بتغاير $\Sigma = U\Lambda U^{\top}$؛ نريد تحويلاً W يجعل التغاير I. المطلوب: صيغة W وتفسيرها بالأساس.

الحل: الخطوة 1: تغيير أساس: $z_1 = U^{\top}x \Longrightarrow$ التغاير Λ (قطري $\Longrightarrow$ غير مترابط). الخطوة 2: قياس المحاور: $z_2 = \Lambda^{-1/2}z_1 \Longrightarrow$ التغاير I. الخطوة 3: إذن $W = \Lambda^{-1/2}U^{\top}$ (PCA whitening)؛ يُضيف ZCA في النهاية: U

$W_{\text{ZCA}} = U\Lambda^{-1/2}U^\top$. الخطوة 4: تحقق: $W\Sigma W^\top = I$ ✓.

النتيجة: التبييض = تدوير (أساس) + قياس (محاور) [+ تدوير عكسي]. الربط بالذكاء الاصطناعي: هذا تطبيق مباشر لـ (5.3): W هي مصفوفة تغيير أساس مضروبة في مصفوفة قياس قطرية، وكلها خطية $\Longrightarrow$ تُدمج في طبقة واحدة.

مثال (1.3-15): متوسط التجميع (Average Pooling) كمصفوفة

المعطيات: نافذة تجميع 2×2 على خريطة 4×4 $\Longrightarrow$ مخرج 2×2. المطلوب: مصفوفة التجميع وعدد العناصر غير الصفرية.

الحل: الخطوة 1: المخرج 4 قيم، كل واحدة = متوسط 4 مدخلات $\Longrightarrow$ $M \in \mathbb{R}^{4\times 16}$. الخطوة 2: كل صف فيه 4 قيم $\frac{1}{4}$ و 12 صفراً $\Longrightarrow$ 16 عنصراً غير صفري من 64. الخطوة 3: M ليست مربّعة ولا قابلة للعكس $\Longrightarrow$ معلومات تُفقد (عدمية = 12). الخطوة 4: الناظم التشغيلي $\|M\|_{\text{op}} = 1$ (لا يكبّر الإشارة).

النتيجة: تجميع = إسقاط خطي غير قابل للعكس بنسبة فقدان 75% من الأبعاد. الربط بالذكاء الاصطناعي: هذا يفسّر لماذا التجميع يسبّب فقدان معلومات موضعية، ومنه ظهرت بدائل «التجميع بالانتباه» و convolutions strided القابلة للتعلّم.

6.1.3 أخطاء شائعة

الخطأ	الصواب
قراءة المصفوفة صفّاً صفّاً	**الأعمدة** هي صور متجهات الأساس
افتراض $S \circ T$ يعطي TS	الترتيب معكوس: $[S \circ T] = [S][T]$
نسيان Q^{-1} في (5.3)	تغيير أساس المدى يحتاج **المعكوس**
ظنّ أن $P^{-1}AP$ يغيّر التحويل	يغيّر التمثيل فقط؛ الطيف محفوظ

الأهمية: المحدّد هو الرقم الوحيد الذي يخبرك: «كم تضخّم هذا التحويل الحجم؟ وهل قلب الاتجاه؟ وهل يمكن عكسه؟» — وهو حجر الزاوية في النماذج التوليدية التدفقية وفي توزيعات الاحتمال متعددة المتغيّرات.

1.2.3 الصياغة الرسمية

التعريف بصيغة التبديلات:

$$\det(A) \;=\; \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) \prod_{i=1}^{n} A_{i,\sigma(i)} \tag{9.3}$$

الخصائص الأساسية:

$$\det(AB) \;=\; \det(A)\,\det(B) \tag{10.3}$$

$$\det(A^\top) \;=\; \det(A), \qquad \det(A^{-1}) \;=\; \frac{1}{\det(A)} \tag{11.3}$$

$$\det(cA) \;=\; c^{\,n}\det(A) \quad (A \in \mathbb{R}^{n\times n}) \tag{12.3}$$

$$\det\begin{bmatrix} A & C \\ 0 & B \end{bmatrix} \;=\; \det(A)\,\det(B) \tag{13.3}$$

قابلية العكس:

$$A \text{ قابلة للعكس} \iff \det(A) \neq 0 \iff \operatorname{rank}(A) = n \tag{14.3}$$

المعنى الهندسي (تضخّم الحجم):

$$\operatorname{Vol}\big(T(\Omega)\big) \;=\; \big|\det(A)\big|\;\operatorname{Vol}(\Omega) \tag{15.3}$$

العلاقة بالطيف:

$$\det(A) \;=\; \prod_{i=1}^{n} \lambda_i \tag{16.3}$$

قاعدة كرامر:

$$x_j \;=\; \frac{\det(A_j)}{\det(A)}, \qquad A_j = A \text{ بعد استبدال عمودها } j \text{ بـ } b \tag{17.3}$$

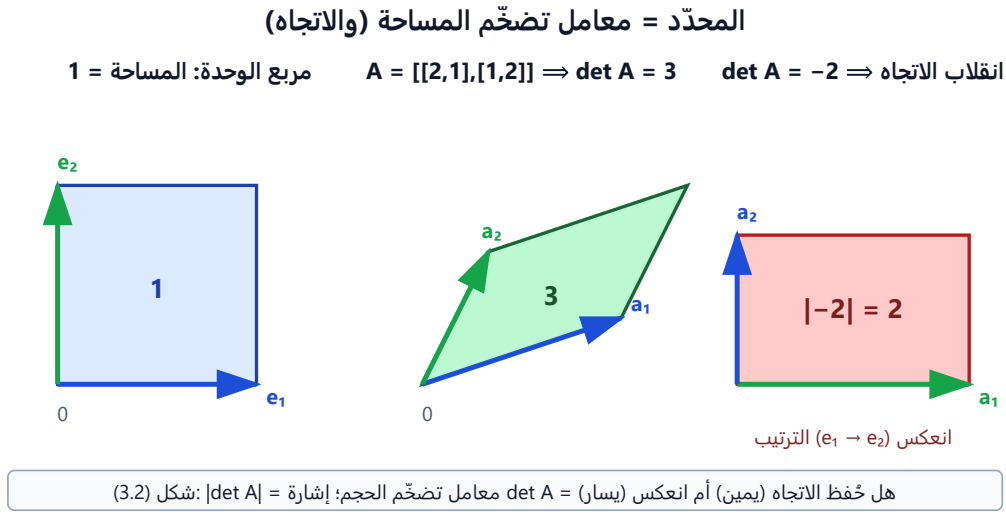
المحدّد في تغيير المتغيّرات (Jacobian):

$$p_Y(y) \;=\; p_X(x)\,\big|\det J_f(x)\big|^{-1}, \qquad J_f(x) = \frac{\partial f(x)}{\partial x} \tag{18.3}$$

$$\log p_Y(y) \;=\; \log p_X(x) \;-\; \log\big|\det J_f(x)\big| \tag{19.3}$$

2.2.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
$\det(A)$ أو $\lvert A\rvert$	المحدّد	رقم قياسي	ليس قيمة مطلقة
σ	تبديلة (permutation)	عنصر من الزمرة المتماثلة S_n	عددها $n!$
$\operatorname{sgn}(\sigma)$	إشارة التبديلة	$+1$ (زوجية) أو -1 (فردية)	—
S_n	الزمرة المتماثلة	كل تبديلات $\{1,\dots,n\}$	—
$\lvert\det A\rvert$	معامل تضخّم الحجم	نسبة الحجم بعد التحويل	(15.3)
J_f	مصفوفة يعقوبي	مشتقات جزئية للتحويل f	jacobian
λ_i	القيمة الذاتية i	جذر متعددة الحدود المميّزة	الفصل 4
A_j	مصفوفة كرامر	A بعمود j مستبدل	(17.3)
Vol	الحجم	قياس لبesgue في $\mathbb{R}^n$	—
$\det_\varepsilon$	المحدّد العددي	$\prod$ القيم المفردة التي $> \varepsilon$	عملياً: slogdet



شكل ٢.٣: *
المحدّد ومساحة

3.2.3 الشكل الهندسي

شكل (2.3): مربع الوحدة (مساحة 1) يتحول إلى متوازي أضلاع مساحته $|\det A| = 3$ مع حفظ الاتجاه، أو إلى متوازٍ مساحته 2 مع **انقلاب** الاتجاه عند $\det < 0$.

4.2.3 البرهان

خصائص (10.3)–(13.3): تُشتقّ من التعريف البديهي للمحدّد: الدالة الوحيدة المتعددة الخطية في الأعمدة، المتبادلة الإشارة عند تبديل عمودين، والمعيّرة بـ $\det(I) = 1$.

- **(10.3):** نُثبت أن $D(B) = \det(AB)/\det(A)$ تحقق البديهيات الثلاث كمؤثّر في أعمدة $B \implies D(B) = \det(B)$ $\det(AB) = \det(A)\det(B)$.
- **(11.3):** $\det(A) = \det(A^\top)$ فوراً من (9.3) لأن $\prod_i A_{\sigma^{-1}(i),i} = \prod_i A_{i,\sigma(i)}$ و $\operatorname{sgn}(\sigma) = \operatorname{sgn}(\sigma^{-1})$.
- **(13.3):** بحذف غاوس على المصفوفة الكتلية المثلثية، أو بتوسيع لابلاس المتكرّر.

(15.3): مربع الوحدة يتحوّل إلى متوازي السطوح المولَّد بأعمدة A، وحجمه يُحسب بجداء «الارتفاعات المتعامدة» الذي يساوي $|\det A|$ (وهو ما يُثبت بغرام–شميدت: $|\det A| = \prod_j \|w_j\|$ من الفصل 2).
(14.3): A قابلة للعكس $\iff$ أعمدتها مستقلة $\iff \operatorname{rank} = n$؛ وبـ $|\det A| = \prod_j \|w_j\|$ من غرام–شميدت $\implies$ المحدّد $\neq 0 \iff$ لا ينهار أي $w_j \iff$ استقلال. ■

5.2.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (3.2.1-1): تغيّر الحجم في النماذج التدفقية (Normalizing Flows)

المعطيات: تحويل تدفقي $y = f(x)$؛ يعقوبي بمحدّد $|\det J| = 2.5$؛ كثافة المصدر $p_X(x) = 0.4$. المطلوب: كثافة المخرج $p_Y(y)$ و $\log p_Y$.

الحل: الخطوة 1: بـ (3.18): $p_Y(y) = p_X(x)/|\det J| = 0.4/2.5 = 0.16$. الخطوة 2: $\log p_Y = \log 0.4 - \log 2.5 = -0.916 - 0.916 = -1.833$. الخطوة 3: التفسير: التحويل «وسّع» الحجم $\Rightarrow$ خفّض الكثافة.

النتيجة: $p_Y = 0.16$، $\log p_Y = -1.833$. الربط بالذكاء الاصطناعي: هذه المتطابقة هي دالة الهدف الكاملة لتدريب النماذج التدفقية؛ وكل تصميم معماري (RealNVP، Flows Glow، مستمرة) يُصمَّم ليكون حساب $\log|\det J|$ رخيصاً (مثلثية $\Rightarrow$ جداء القطر).

مثال (3.2.2-2): شرط قابلية العكس في الانحدار

المعطيات: ميزتان: المساحة بالمتر^2 وبالقدم^2 (القدم^2 = 0.0929 متر^2). المطلوب: هل يمكن عكس $X^\top X$؟

الحل: الخطوة 1: العمودان مضاعفا بعضهما $\Rightarrow \operatorname{rank}(X^\top X) = 1 < 2$. الخطوة 2: بـ (3.14): $\det(X^\top X) = 0$ $\Rightarrow$ غير قابلة للعكس. الخطوة 3: عملياً: القيمة الذاتية الثانية $\approx 10^{-16}$ (ضجيج عائم) $\Rightarrow \det \approx 10^{-16}$. الخطوة 4: العلاج: $\det(X^\top X + \lambda I) > 0 \Rightarrow$ Ridge.

النتيجة: غير قابلة للعكس؛ الحلّ Ridge. الربط بالذكاء الاصطناعي: فحص det أو أصغر قيمة ذاتية هو تشخيص مباشر لتعدد الخطي؛ والعتبة العملية هي $\lambda_{\min} > 10^{-10}\lambda_{\max}$.

مثال (3.2.3-3): المحدّد كـ «التباين المعمّم» للتوزيع الغاوسي

المعطيات: توزيع غاوسي ثنائي الأبعاد بمصفوفة تغاير $\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$. المطلوب: حساب $\det \Sigma$ وثابت التطبيع.

الحل: الخطوة 1: $\det \Sigma = 4 \cdot 3 - 2 \cdot 2 = 12 - 4 = 8$. الخطوة 2: الثابت $= \frac{1}{(2\pi)^{d/2}\sqrt{\det \Sigma}} = \frac{1}{2\pi\sqrt{8}} = 0.0563$. الخطوة 3: $\det \Sigma = 8$ هو «التباين المعمّم»: مساحة قطع الناقص الإهليلجي (ellipse) المحتوي على 95% من الكتلة تتناسب مع $\sqrt{8}$.

النتيجة: ثابت التطبيع 0.0563؛ التباين المعمّم 8. الربط بالذكاء الاصطناعي: $\log\det\Sigma$ يظهر في كل حساب احتمالي غاوسي (VAE، Gaussian mixture، كالمان)؛ وصغره المفرط يعني «انهيار التباين» (variance collapse).

مثال (3.2.4-4): اختبار اتجاه معايرة الكاميرا

المعطيات: مصفوفة دوران مقدَّرة $\hat{R}$ بـ $\det(\hat{R}) = -1.0003$. المطلوب: هل التقدير صالح؟

الحل: الخطوة 1: مصفوفة الدوران الصحيحة عنصر من $SO(3) \Longrightarrow \det = +1$ بالضبط. الخطوة 2: $\det = -1$ $\Longrightarrow$ المصفوفة **انعكاس** (مرآة) لا دوران $\Longrightarrow$ الصورة مقلوبة. الخطوة 3: السبب المعتاد: تقدير خاطئ للإشارة أو أعمدة متبادلة. الخطوة 4: التصحيح: نأخذ العامل المتعامد من التفكك القطبي (القسم 5.3) مع فرض $\det > 0$.

النتيجة: غير صالح؛ انعكاس لا دوران. الربط بالذكاء الاصطناعي: اختبار $\det R > 0$ فحص صحّة إلزامي في كل أنظمة الرؤية الحاسوبية والروبوتات قبل استخدام المصفوفة.

مثال (3.2-5): حجم متوازي السطوح لتضمينات الكلمات

المعطيات: ثلاث كلمات تضميناتها $v_1 = (1,0,0)$، $v_2 = (0,2,0)$، $v_3 = (0,0,3)$. المطلوب: حجم متوازي السطوح المولَّد، وتفسيره الدلالي.

الحل: الخطوة 1: $A = [v_1\ v_2\ v_3] = \operatorname{diag}(1,2,3) \Longrightarrow \det A = 6$. الخطوة 2: الحجم $= |6| = 6$. الخطوة 3: لو كانت التضمينات متقاربة جداً (شبه متوازية): $\det \approx 0 \Longrightarrow$ «حجم دلالي» صغير.

النتيجة: حجم = 6، ومحدّد صغير $\Longrightarrow$ تضمينات مترابطة (فقدان تنوّع). الربط بالذكاء الاصطناعي: قياس det (أو det لمصفوفة غرام) مقياس لتنوّع التمثيل، ويُستخدم في تحليل «انهيار التمثيل» في التعلّم الذاتي الإشراف.

مثال (3.2-6): انهيار المحدّد في مصفوفة الميزات

المعطيات: مصفوفة ميزات $X \in \mathbb{R}^{1000\times 12}$، القيم المفردة $(50,\ 40,\ 30,\ \ldots,\ 2,\ 10^{-13})$. المطلوب: هل المصفوفة قابلة للعكس عملياً؟

الحل: الخطوة 1: $\det(X^\top X) = \prod_i \sigma_i^2 \Longrightarrow$ يضمّ عامل $10^{-26} \Longrightarrow \det \approx 0$. الخطوة 2: عدد الحالة $\kappa = 50/10^{-13} = 5\times 10^{14} \Longrightarrow$ كارثي. الخطوة 3: $\Longrightarrow$ لا يمكن عكسها بدقة مضاعفة.

النتيجة: غير قابلة للعكس عملياً. الربط بالذكاء الاصطناعي: **درس:** لا تستخدم det مباشرةً للحكم (يتلاشى سريعاً)؛ استخدم $\log\det = \sum \log \sigma_i^2$ أو عدد الحالة.

مثال (3.2-7): مساحة منطقة القرار

المعطيات: مصنّف خطي ثنائي الأبعاد، منطقة القرار الموجبة مضلع مساحته 12 وحدة^2؛ نُطبّق تحويل ميزات بمصفوفة A بـ $|\det A| = 0.3$. المطلوب: مساحة المنطقة بعد التحويل.

الحل: الخطوة 1: بـ (15.3): المساحة الجديدة $= 12 \times 0.3 = 3.6$. الخطوة 2: التحويل «ضغط» الفضاء $\Longrightarrow$ المنطقة تقلّصت إلى 30%. الخطوة 3: لو كان $|\det A| = 0 \Longrightarrow$ المنطقة تنهار إلى مستوٍ/مستقيم $\Longrightarrow$ لا يمكن فصل الأصناف.

النتيجة: 6.3 وحدة^2. الربط بالذكاء الاصطناعي: انهيار حجم فضاء الميزات يعني فقدان القدرة على الفصل؛ وهو ما يُقاس في الشبكات العميقة بـ «انهيار الأبعاد» (dimensional collapse).

مثال (3.2.8): اختبار المشتقة الثانية بمحدّد الهِسّية

المعطيات: دالة خسارة $\mathcal{L}(\theta_1, \theta_2)$ عند نقطة حرجة $(\nabla\mathcal{L} = 0)$ بهِسّية $H = \begin{bmatrix} 2 & 0 \\ 0 & -3 \end{bmatrix}$. المطلوب: تصنيف النقطة.

الحل: الخطوة 1: $\det H = 2(-3) - 0 = -6 < 0$. الخطوة 2: القيم الذاتية $(2, -3)$ إشارات مختلفة $\Longrightarrow$ **نقطة سرجية** (saddle). الخطوة 3: القاعدة: $\det H > 0$ و $H_{11} > 0 \Longrightarrow$ أصغر موضعي؛ $\det H > 0$ و $H_{11} < 0 \Longrightarrow$ أعظمي؛ $\det H < 0 \Longrightarrow$ سرجية.

النتيجة: نقطة سرجية. الربط بالذكاء الاصطناعي: في الشبكات العميقة النقاط السرجية أكثر شيوعاً من الأصغريات السيّئة في الأبعاد العالية؛ ولهذا نجحت طرق التدرّج رغم عدم-convexity.

مثال (3.2.9): استقرار نظام ديناميكي متقطّع

المعطيات: تحديث حالة الشبكة المتكرّرة الخطية $h_{t+1} = Wh_t$، W بـ $|\det W| = 1.4$. المطلوب: هل النظام مستقر؟

الحل: الخطوة 1: بـ (3.16): $|\det W| = \prod|\lambda_i| = 1.4 > 1$. الخطوة 2: حجم الحالة يتضخّم بمعامل 1.4 كل خطوة $\Longrightarrow$ بعد 20 خطوة: $1.4^{20} \approx 837$. الخطوة 3: $\Longrightarrow$ غير مستقر (ينفجر). الخطوة 4: شرط الاستقرار: كل $|\lambda_i| < 1$ (نصف قطر طيفي < 1).

النتيجة: غير مستقر، انفجار بمعامل 837 بعد 20 خطوة. الربط بالذكاء الاصطناعي: هذه هي الصيغة الدقيقة لمشكلة انفجار التدرّج، وعلاجها جعل القيم المفردة قريبة من 1 (تهيئة متعامدة، تطبيع طيفي).

مثال (3.2.10): تغيير المتغيّرات في توزيع احتمالي

المعطيات: $X \sim \mathcal{N}(0, 1)$، التحويل $Y = 3X + 1$. المطلوب: كثافة Y.

الحل: الخطوة 1: $|\det J| = 3 \Longrightarrow J = \frac{dY}{dX} = 3$. الخطوة 2: العكس: $X = (Y - 1)/3$. الخطوة 3: $p_Y(y) = p_X\left(\frac{y-1}{3}\right) \cdot \frac{1}{3} = \frac{1}{3\sqrt{2\pi}} \exp\left(-\frac{(y-1)^2}{18}\right)$. الخطوة 4: $\Longrightarrow Y \sim \mathcal{N}(1, 9)$ ✓.

النتيجة: $Y \sim \mathcal{N}(1, 9)$. الربط بالذكاء الاصطناعي: هذه المتطابقة هي أساس كل النماذج التوليدية القائمة على الكثافة، وتعميمها على التحويلات غير الخطية يعطي النماذج التدفقية.

مثال (3.2.11): التحويلات الحافظة للحجم (Volume-Preserving)

المعطيات: طبقة coupling في RealNVP: $y_1 = x_1$، $y_2 = x_2 \cdot e^{s(x_1)} + t(x_1)$. المطلوب: حساب $\log|\det J|$ وإثبات رخصه.

الحل: الخطوة 1: اليعقوبي كتلي مثلثي: $J = \begin{bmatrix} I & 0 \\ \frac{\partial y_2}{\partial x_1} & \operatorname{diag}(e^s) \end{bmatrix}$. الخطوة 2: بـ (3.13): $\det J = \det(I) \cdot \det(\operatorname{diag}(e^s)) = \prod_i e^{s_i}$. الخطوة 3: $\log|\det J| = \sum_i s_i \Longrightarrow$ **مجرد جمع!** الخطوة 4: التكلفة $O(d)$ بدل $O(d^3)$.

النتيجة: حساب المحدّد بتكلفة خطية. الربط بالذكاء الاصطناعي: هذا التصميم هو ما جعل النماذج التدفقية عملية، وكل الأجيال اللاحقة (Glow، Flows) Spline Neural Flow++، تحافظ على «يعقوبي مثلثي/قطري».

مثال (3.2-12): محدّد مصفوفة النواة و«المحدّد الزائف»

المعطيات: مصفوفة نواة $K \in \mathbb{R}^{500\times 500}$ موجبة نصف-محددة برتبة 60. المطلوب: كيف نحسب «محدّدها» لأجل حساب الاحتمال؟

الحل: الخطوة 1: $\det K = 0$ لأن الرتبة ناقصة $\Rightarrow$ لا يمكن حساب الكثافة الغاوسية. الخطوة 2: نستخدم **المحدّد الزائف** (pseudo-determinant) = جداء القيم الذاتية غير الصفرية. الخطوة 3: عملياً نضيف تنظيماً: $\det(K + \lambda I)$ مع $\lambda = 10^{-6}$ $\Rightarrow$ محدّد موجب ومستقر. الخطوة 4: $\log\det(K+\lambda I) = \sum_i \log(\lambda_i + \lambda)$ $\Rightarrow$ مستقر رقمياً.

النتيجة: استخدم $\log\det(K + \lambda I)$ لا $\det K$. الربط بالذكاء الاصطناعي: في العمليات الغاوسية (GP) يحسب المرء دائماً $\log\det$ عبر تحليل Cholesky لا المحدّد الخام، لأن det يتجاوز/يتلاشى عددياً بسرعة هائلة.

مثال (3.2-13): اختبار رتبة ميزات صورة

المعطيات: ميزات CNN لأربع صور: $F \in \mathbb{R}^{512\times 4}$، القيم المفردة $(30,\ 20,\ 5,\ 10^{-9})$. المطلوب: هل تمثيلات الصور مستقلة؟

الحل: الخطوة 1: $\det(F^\top F) = \prod \sigma_i^2$ يتضمّن 10^{-18} $\Rightarrow$ شبه صفري. الخطوة 2: الرتبة العددية 3 $\Rightarrow$ الرابعة تركيبة خطية للثلاث الأولى. الخطوة 3: التفسير: صورة ما تُنتج تمثيلاً مكرّراً (صورة مكرّرة أو متطابقة دلالياً).

النتيجة: رتبة 3 من 4 $\Rightarrow$ تمثيل مكرّر. الربط بالذكاء الاصطناعي: كشف التكرار في مجموعات بيانات التدريب الضخمة يُنجز بهذه المؤشرات الطيفية قبل التدريب، ويوفّر أسابيع من الحوسبة.

مثال (3.2-14): عدد الحلول في نظام معادلات

المعطيات: $A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$، $b = \begin{bmatrix} 3 \\ 6 \end{bmatrix}$. المطلوب: عدد الحلول.

الحل: الخطوة 1: $\det A = 4 - 4 = 0$ $\Rightarrow$ غير قابلة للعكس (3.14). الخطوة 2: نفحص الملحقة: $b = 3 \cdot \binom{1}{2}$ والعمود الأول من A هو $\binom{1}{2}$ $\Rightarrow$ متوافق. الخطوة 3: $\operatorname{rank}(A) = \operatorname{rank}([A \mid b]) = 1 < 2$ $\Rightarrow$ **حلول لانهائية** ببعد العدمية $1 - 1 = 2$. الخطوة 4: الحلّ العام: $x = \binom{3}{0} + t\binom{-2}{1}$.

النتيجة: حلول لانهائية على مستقيم. الربط بالذكاء الاصطناعي: هذا هو الوضع المعتاد في الشبكات «المفرطة المعلمات» (over-parameterized): حلول لانهائية تفسّر البيانات تماماً، وتحددها خوارزمية التحسين (implicit bias).

مثال (3.2-15): قاعدة كرامر في مسألة صغيرة

المعطيات: $2x + y = 5$، $x + 3y = 10$. المطلوب: الحلّ بقاعدة كرامر.

الحل: الخطوة 1: $A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \Rightarrow \det A = 6 - 1 = 5$. الخطوة 2: $A_1 = \begin{bmatrix} 5 & 1 \\ 10 & 3 \end{bmatrix} \Rightarrow \det A_1 = 15 - 10 = 5 \Rightarrow x = 5/5 = 1$. الخطوة 3: $A_2 = \begin{bmatrix} 2 & 5 \\ 1 & 10 \end{bmatrix} \Rightarrow \det A_2 = 20 - 5 = 15 \Rightarrow y = 15/5 = 3$.

الخطوة 4: تحقق: $2 + 3 = 5$ ✓ و $1 + 9 = 10$ ✓.

النتيجة: $(x, y) = (1, 3)$. الربط بالذكاء الاصطناعي: كرامر تُستخدم للتدريس فقط — تكلفتها $O(n \cdot n!)$ أو $O(n^4)$، الحلّ العملي دائماً عبر LU/QR/Cholesky بـ $O(n^3)$.

6.2.3 أخطاء شائعة

الخطأ	الصواب
الخلط بين $\|A\|$ (محدّد) وقيمة مطلقة	المحدّد قد يكون سالباً
حساب det للحكم على الرتبة	استخدم القيم المفردة أو log det
افتراض $\det(A+B) = \det A + \det B$	غير صحيح إطلاقاً
نسيان $\|\cdot\|$ في (15.3)	الحجم موجب دائماً $\Rightarrow \|\det\|$

الأهمية: الآثر هو «الرقم الذي ينجو من كل إعادة ترتيب». دوريّته $\mathrm{tr}(ABC) = \mathrm{tr}(BCA)$ هي الأداة التي تُبسّط بها كل تدرّجات المصفوفات في التعلّم العميق، وعلاقته بالقيم الذاتية تجعله مقياساً للحجم الطيفي.

1.3.3 الصياغة الرسمية

التعريف:

$$\mathrm{tr}(A) = \sum_{i=1}^{n} A_{ii} \tag{20.3}$$

الخاصية الدورية (الأهم على الإطلاق):

$$\mathrm{tr}(AB) = \mathrm{tr}(BA) \tag{21.3}$$

$$\mathrm{tr}(ABC) = \mathrm{tr}(BCA) = \mathrm{tr}(CAB) \tag{22.3}$$

$$\mathrm{tr}(A_1 A_2 \cdots A_k) = \mathrm{tr}(A_2 \cdots A_k A_1) \tag{23.3}$$

تحذير: الدورية تسمح بتدوير العوامل، لا بتبديلها عشوائياً. $\mathrm{tr}(ABC) \neq \mathrm{tr}(ACB)$ عموماً.

العلاقة بالطيف:

$$\operatorname{tr}(A) \;=\; \sum_{i=1}^{n} \lambda_i, \qquad \det(A) \;=\; \prod_{i=1}^{n} \lambda_i \tag{24.3}$$

الثبات تحت التشابه:

$$\operatorname{tr}(P^{-1}AP) \;=\; \operatorname{tr}(A) \tag{25.3}$$

العلاقة بناظم فروبنيوس والجداء الداخلي الماتريسي:

$$\|A\|_F^2 \;=\; \operatorname{tr}(A^{\top}A) \;=\; \sum_{ij} A_{ij}^2 \tag{26.3}$$

$$\langle A,\, B\rangle_F \;=\; \operatorname{tr}(A^{\top}B) \tag{27.3}$$

الآثر في التفاضل الماتريسي (سيُستخدم بكثافة في الفصل 9):

$$\frac{\partial}{\partial A}\operatorname{tr}(AB) \;=\; B^{\top}, \qquad \frac{\partial}{\partial A}\operatorname{tr}(A^{\top}B) \;=\; B \tag{28.3}$$

$$d\big(\log\det A\big) \;=\; \operatorname{tr}\big(A^{-1}\,dA\big) \tag{29.3}$$

2.3.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
$\operatorname{tr}(\cdot)$	الآثر	مجموع القطر	np.trace
λ_i	القيمة الذاتية i	جذر تعددية الحدود المميّزة	الفصل 4
$\|\cdot\|_F$	ناظم فروبنيوس	جذر مجموع المربعات	(26.3)
$\langle\cdot,\cdot\rangle_F$	الجداء الداخلي الماتريسي	$\operatorname{tr}(A^{\top}B)$	«ضرب قياسي للمصفوفات»
dA	تفاضل المصفوفة	تغيّر صغير في A	الفصل 9
$\frac{\partial}{\partial A}$	المشتقة الماتريسية	مصفوفة بنفس شكل A	—
P	مصفوفة تغيير أساس	قابلة للعكس	(25.3)
tr_k	آثر جزئي	مجموع أكبر k قيم ذاتية	يُستخدم في التنظيم النووي

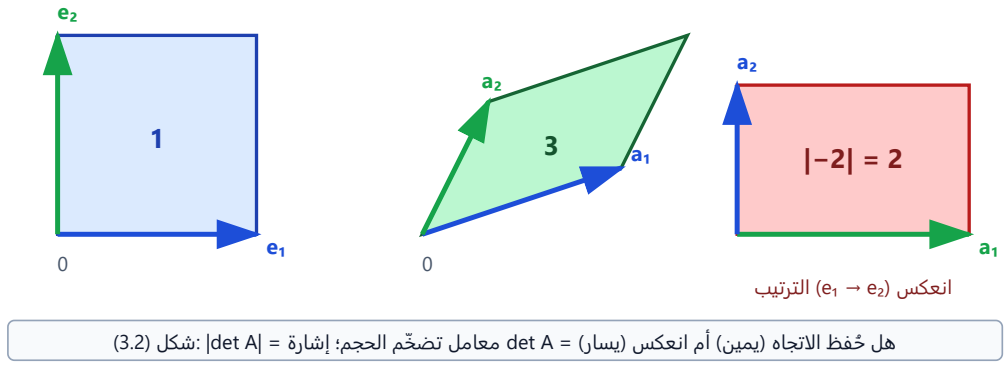
3.3.3 الشكل الهندسي

شكل (3.3) (بالاستعانة بالشكل 2.3): إذا كان التحويل يمدّد المحاور بمعاملات σ_1, σ_2، فإن **المحدّد** = جداء المعاملات (الحجم) والآثر (للأجزاء المتماثلة) = مجموعها (مجموع التمددات الطيفية).

4.3.3 البرهان

(21.3) الدورية الثنائية:

$$\operatorname{tr}(AB) \;=\; \sum_i (AB)_{ii} \;=\; \sum_i \sum_j A_{ij}B_{ji} \;=\; \sum_j \sum_i B_{ji}A_{ij} \;=\; \sum_j (BA)_{jj} \;=\; \operatorname{tr}(BA)$$



شكل ٣.٣: *
الآثر والمحدّد

الخطوة الحاسمة هي تبديل ترتيب الجمعين (مسموح للمصفوفات المنتهية).

(22.3) الثلاثية: نُطبّق (21.3) على A و (BC): $\operatorname{tr}(A(BC)) = \operatorname{tr}((BC)A) = \operatorname{tr}(BCA)$؛ وبالمثل على (AB) و C: $\operatorname{tr}((AB)C) = \operatorname{tr}(C(AB)) = \operatorname{tr}(CAB)$.

(25.3) الثبات تحت التشابه: بـ (22.3) مع ثلاثة عوامل:

$$\operatorname{tr}(P^{-1}AP) \;=\; \operatorname{tr}(APP^{-1}) \;=\; \operatorname{tr}(AI) \;=\; \operatorname{tr}(A)$$

(24.3): متعددة الحدود المميّزة $p(\lambda) = \det(\lambda I - A) = \lambda^n - \operatorname{tr}(A)\lambda^{n-1} + \cdots + (-1)^n \det(A)$؛ ومقارنةً بـ $\prod(\lambda - \lambda_i)$ نحصل على أن معامل λ^{n-1} هو $-\sum \lambda_i \Longrightarrow \operatorname{tr}(A) = \sum \lambda_i$، والحدّ الثابت يعطي $\det(A) = \prod \lambda_i$. ■

5.3.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-3.3): التباين الكلي = آثر مصفوفة التغاير

المعطيات: ميزات ثلاثية بتغاير $\Sigma = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 3 & 0.5 \\ 0 & 0.5 & 2 \end{bmatrix}$. المطلوب: التباين الكلي.

الحل: الخطوة 1: $\operatorname{tr}(\Sigma) = 4 + 3 + 2 = 9$. الخطوة 2: التباين الكلي $= 9$ (وهو أيضاً $\sum \lambda_i$ بالصيغة 24.3).
الخطوة 3: في PCA: نسبة التباين المفسَّر بـ k مركبة $= \sum_{i \le k} \lambda_i / \operatorname{tr}(\Sigma)$.
النتيجة: التباين الكلي = 9. الربط بالذكاء الاصطناعي: هذه هي الصيغة التي تجعل اختيار k في PCA مسألة حساب مباشر: نُجمّع القيم الذاتية حتى نبلغ 95% من $\operatorname{tr}(\Sigma)$.

مثال (3.3-2): تنظيم L_2 (weight decay) كآثر

المعطيات: أوزان طبقة $W \in \mathbb{R}^{128\times 256}$؛ نريد حساب $\|W\|_F^2$ بدقة وكفاءة. المطلوب: صيغة الآثر وسبب استخدامها.

الحل: الخطوة 1: بـ (26.3): $\|W\|_F^2 = \operatorname{tr}(W^\top W)$. الخطوة 2: $W^\top W \in \mathbb{R}^{256\times 256}$ $\Longrightarrow$ آثرها = مجموع قيمها الذاتية = مجموع مربعات القيم المفردة $\sum \sigma_i^2$. الخطوة 3: الحساب المباشر $\sum_{ij} W_{ij}^2$ يكلف $O(mn)$؛ أما عبر القيم المفردة فـ $O(mn^2)$ $\Longrightarrow$ الحساب المباشر أرخص. الخطوة 4: لكن صيغة الآثر مفيدة في **الاشتقاق**: $\frac{\partial}{\partial W}\operatorname{tr}(W^\top W) = 2W$.

النتيجة: weight decay $\lambda \operatorname{tr}(W^\top W)$ $=$ وتدرّجه $2\lambda W$. الربط بالذكاء الاصطناعي: كل تنظيمات المصفوفات في أطر العمل تُكتب داخلياً بصيغة الآثر لأن تدرّجها بسيط وعام.

مثال (3.3-3): خسارة إعادة الإعمار بالآثر

المعطيات: $\|X - \hat{X}\|_F^2$ حيث $\hat{X} = U_k U_k^\top X$. المطلوب: تبسيط الخسارة بالآثر.

الحل: الخطوة 1: $\|X-\hat{X}\|_F^2 = \operatorname{tr}\big((X-\hat{X})^\top(X-\hat{X})\big)$. الخطوة 2: نوسّع: $= \operatorname{tr}(X^\top X) - 2\operatorname{tr}(X^\top \hat{X}) + \operatorname{tr}(\hat{X}^\top \hat{X})$. الخطوة 3: بـ $\hat{X} = P_k X$ و $P_k^2 = P_k$: $= \operatorname{tr}(X^\top X) - \operatorname{tr}(X^\top P_k X)$. الخطوة 4: $= \|X\|_F^2 - \sum_{i\le k}\sigma_i^2$.

النتيجة: خطأ إعادة الإعمار $\sum_{i>k}\sigma_i^2$ $=$. الربط بالذكاء الاصطناعي: هذه الصيغة تجعل حساب منحنى «التباين المفسَّر» فورياً من طيف القيم المفردة، دون إعادة بناء البيانات.

مثال (3.3-4): درجات الحرية الفعّالة في Ridge

المعطيات: انحدار Ridge، مؤثّر القبعة $H_\lambda = X(X^\top X + \lambda I)^{-1}X^\top$ بقيم ذاتية $(0.99,\ 0.95,\ 0.85,\ 0.6,\ 0.2)$.

المطلوب: درجات الحرية الفعّالة.

الحل: الخطوة 1: درجات الحرية $= \operatorname{tr}(H_\lambda)$ (بـ 24.3: مجموع القيم الذاتية). الخطوة 2: $= 0.99+0.95+0.85+0.6+0.2 = 3.59$. الخطوة 3: مقابل 5 بدون تنظيم $\Longrightarrow$ التنظيم «أزال» 41.1 درجة حرية.

النتيجة: 59.3 درجة حرية فعّالة. الربط بالذكاء الاصطناعي: $\operatorname{tr}(H_\lambda)$ هو مقياس التعقيد الفعّال المستخدم في AIC/BIC، وكلما صغر كان النموذج أبسط وأقلّ فرط تخصيص.

مثال (3.3-5): متوسط الخسارة عبر المهام بالآثر

المعطيات: مصفوفة خسائر $L \in \mathbb{R}^{8\times 1000}$ (8 مهام × 1000 عيّنة)؛ نريد متوسطاً مرجّحاً بأوزان المهام $w \in \mathbb{R}^8$.

المطلوب: صيغة ماتريسية موجزة.

الحل: الخطوة 1: المتوسط المرجّح $\frac{1}{1000}\sum_i w_i \sum_j L_{ij}$ $=$ $\sum_i w_i \bar{L}_i$ $=$. الخطوة 2: بصيغة الآثر:

$\frac{1}{1000}\operatorname{tr}(\operatorname{diag}(w)\,L\,\mathbf{1}\mathbf{1}^\top)$ =. الخطوة 3: بالدورية (22.3): $\frac{1}{1000}\operatorname{tr}(\mathbf{1}^\top\operatorname{diag}(w)L)$ = $\Longrightarrow$ شكل أرخص للحساب. الخطوة 4: التدرّج على L: بـ (28.3) $\frac{1}{1000}\operatorname{diag}(w)\mathbf{1}\mathbf{1}^\top$ $\Longrightarrow$ مصفوفة رتبتها 1.

النتيجة: صيغة موجزة وتدرّج من رتبة 1. الربط بالذكاء الاصطناعي: صياغة الخسائر بالآثر تجعل الاشتقاق الآلي على GPU أبسط وأسرع من حلقات على المهام.

مثال (3.3-6): الدورية تُبسّط تدرّجاً ماتريسياً

المعطيات: $f(W)=\operatorname{tr}(W^\top AWB)$ مع A متماثلة و B متماثلة. المطلوب: حساب $\frac{\partial f}{\partial W}$.

الحل: الخطوة 1: نأخذ التفاضل: $df = \operatorname{tr}(dW^\top AWB) + \operatorname{tr}(W^\top A\,dW\,B)$. الخطوة 2: بالدورية وبـ $\operatorname{tr}(M)=\operatorname{tr}(M^\top)$: الحدّ الأول $\operatorname{tr}((AWB)^\top dW)^\top = \operatorname{tr}(dW^\top AWB)$ =... نعيد الكتابة: $\operatorname{tr}(BW^\top A\,dW)$ =. الخطوة 3: الحدّ الثاني بالدورية: $\operatorname{tr}(B^\top W^\top A^\top dW) = \operatorname{tr}(BW^\top A\,dW)$ =. الخطوة 4: إذن $df = \operatorname{tr}\big((AWB+AWB^\top)^\top dW\big)$... بتماثل A,B: $\Longrightarrow = \operatorname{tr}\big((AWB+AWB)^\top dW\big)$ $\frac{\partial f}{\partial W} = AWB + A^\top WB^\top = 2AWB$.

النتيجة: $\nabla_W f = 2AWB$ (بتماثل A,B). الربط بالذكاء الاصطناعي: هذه هي التقنية القياسية لاشتقاق تدرّجات طبقات الانتباه والتطبيع الدفعي؛ بدون الدورية تصبح الحسابات غير قابلة للإدارة.

مثال (3.3-7): ثبات الآثر عند تغيير الأساس — تتبع مصفوفة الانتباه

المعطيات: مصفوفة انتباه $A\in\mathbb{R}^{L\times L}$؛ نعيد ترتيب الرموز (تبديل P). المطلوب: هل يتغيّر $\operatorname{tr}(A)$؟

الحل: الخطوة 1: إعادة الترتيب تعطي $A' = PAP^{-1}$ (أو $PAP^\top$ للتبديل). الخطوة 2: بـ (25.3): $\operatorname{tr}(A') = \operatorname{tr}(A)$ $\Longrightarrow$ **لا يتغيّر**. الخطوة 3: التفسير الدلالي: $\operatorname{tr}(A) = \sum_t A_{tt}$ = مجموع أوزان الانتباه الذاتي $\Longrightarrow$ مقياس لـ «مقدار انتباه كل رمز لنفسه».

النتيجة: ثابت تحت التبديل $\Longrightarrow$ مقياس موثوق. الربط بالذكاء الاصطناعي: «الانتباه الذاتي المتوسط» مقياس مستخدم لتشخيص المحوّلات (مثلاً: النماذج المدربة تميل إلى انتباه ذاتي عالٍ على الرمز الأول — attention sink).

مثال (3.3-8): خسارة KL في VAE بالآثر

المعطيات: توزيع خلفي غاوسي $\mathcal{N}(\mu,\Sigma)$ في $\mathbb{R}^k$ ونريد تباعد KL عن $\mathcal{N}(0,I)$. المطلوب: صيغة KL بالآثر والمحدّد.

الحل: الخطوة 1: الصيغة المعروفة: $D_{KL}=\frac{1}{2}\Big[\operatorname{tr}(\Sigma)+\mu^\top\mu-k-\log\det\Sigma\Big]$. الخطوة 2: تحقق بالحالة القياسية $\mu=0,\ \Sigma=I$: $\operatorname{tr}(I)=k$، $\log\det I=0 \Longrightarrow D_{KL}=\frac{1}{2}[k+0-k-0]=0$ ✓. الخطوة 3: الحالة القطرية $\Sigma=\operatorname{diag}(\sigma_i^2)$: $\Longrightarrow = \frac{1}{2}\sum_i(\sigma_i^2-1-\log\sigma_i^2)$ = كل بُعد يُسهم بشكل مستقل.

النتيجة: KL تجمع «الآثر» (الحجم) و «لوغاريتم المحدّد» (الحجم الطيفي). الربط بالذكاء الاصطناعي: هذه الصيغة هي التي تُنفَّذ فعلياً في كل تطبيقات VAE، و $\operatorname{tr}(\Sigma)-\log\det\Sigma$ هو «عقوبة الانحراف عن الهوية» الشهيرة.

مثال (3.3-9): الناظم النووي وإكمال المصفوفة

المعطيات: مصفوفة تفاعلات ناقصة M، نُقرّبها بإكمال منخفض الرتبة بالناظم النووي $\|M\|_* = \operatorname{tr}(\sqrt{M^\top M})$. المطلوب: العلاقة بالقيم المفردة وسبب استخدامه.

الحل: الخطوة 1: $\sqrt{M^\top M}$ قيمها الذاتية = القيم المفردة $\sigma_i \Longrightarrow$ بـ (24.3): $\operatorname{tr}(\sqrt{M^\top M}) = \sum_i \sigma_i$. الخطوة 2: الناظم النووي هو الاسترخاء المحدّب الأمثل للرتبة (الفصل 22). الخطوة 3: مقارنة: $\|M\|_F = \sqrt{\sum \sigma_i^2}$ (يُفضّل توزيعاً متساوياً)؛ $\|M\|_*$ (يُفضّل التناثر الطيفي $\Longrightarrow$ رتبة منخفضة).

النتيجة: $\|M\|_* = \sum \sigma_i$ = بديل محدّب للرتبة. الربط بالذكاء الاصطناعي: إكمال المصفوفة بالناظم النووي هو الأساس النظري لأنظمة التوصية القائمة على التحليل العواملي المحدّب، وله ضمانات استرداد دقيقة.

مثال (3.3-10): معلومات فيشر وآثرها

المعطيات: نموذج احتمالي بمعلومات فيشر $F \in \mathbb{R}^{p\times p}$، نريد مقياساً عددياً لـ «مقدار المعلومات». المطلوب: أي مقياس نستخدم؟

الحل: الخطوة 1: $\operatorname{tr}(F) = \sum_i \lambda_i \Longrightarrow$ مجموع المعلومات على كل الاتجاهات. الخطوة 2: $\log\det F \Longrightarrow$ الحجم (يحسّ «الاتجاهات المهملة»). الخطوة 3: الاتجاهات ذات $\lambda_i \approx 0$ = معلمات لا تؤثّر في التوزيع $\Longrightarrow$ يمكن تقليمها. الخطوة 4: $\operatorname{tr}(F)$ يظهر في حدود Cramér–Rao متعددة المتغيّرات.

النتيجة: $\operatorname{tr}(F)$ للمعلومات الكلية، $\log\det F$ للحجم. الربط بالذكاء الاصطناعي: هذه المقاييس تُستخدم في تقليم النماذج المبني على معلومات فيشر (optimal brain damage/surgeon) وفي التحسين الطبيعي (Natural Gradient).

مثال (3.3-11): آثر المصفوفة المركزية ودرجات الحرية

المعطيات: مصفوفة التوسيط $H_c = I - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$ مع $n = 100$. المطلوب: حساب $\operatorname{tr}(H_c)$.

الحل: الخطوة 1: $\operatorname{tr}(I) = 100$. الخطوة 2: $\operatorname{tr}(\frac{1}{n}\mathbf{1}\mathbf{1}^\top) = \frac{1}{n}\operatorname{tr}(\mathbf{1}^\top\mathbf{1})$ بالدورية (21.3) $= 1 \cdot 100 = \frac{1}{100}\cdot$. الخطوة 3: إذن $\operatorname{tr}(H_c) = 100 - 1 = 99$. الخطوة 4: التفسير: فقدنا درجة حرية واحدة (المتوسط).

النتيجة: 99 = عدد درجات الحرية بعد التوسيط. الربط بالذكاء الاصطناعي: هذا هو سبب القسمة على $n-1$ لا n في تقدير التباين: H_c رتبتها $n-1 \Longrightarrow$ آثرها $n-1$.

مثال (3.3-12): حساب تدرّج خسارة ماتريسية بالآثر

المعطيات: $\mathcal{L}(W) = \operatorname{tr}(W^\top W R) - 2\operatorname{tr}(W^\top C)$ مع R متماثلة. المطلوب: إيجاد W الأمثل.

الحل: الخطوة 1: بـ (28.3): $\frac{\partial}{\partial W}\operatorname{tr}(W^\top W R) = WR + WR^\top = 2WR$ (بتماثل R). الخطوة 2: $\frac{\partial}{\partial W}(-2\operatorname{tr}(W^\top C)) = -2C$. الخطوة 3: نساوي بالصفر: $2WR - 2C = 0 \Longrightarrow W^\star = CR^{-1}$ (إن كانت R

قابلة للعكس). الخطوة 4: هذه هي بالضبط معادلة Wiener/LQR في التحكم الأمثل.

النتيجة: $W^\star = CR^{-1}$. الربط بالذكاء الاصطناعي: معظم مسائل «المربعات الصغرى الخطية» تُحلّ بهذه الطريقة؛ وكتابتها بالآثر تجعل التدرّج فورياً بدل التفاضل العنصري.

مثال (3.3-13): محاذاة النواة (Kernel Alignment)

المعطيات: نواتان $K_1, K_2 \in \mathbb{R}^{n\times n}$ متماثلتان موجبتان نصف-محدّدتين. المطلوب: مقياس تشابه بينهما.

الحل: الخطوة 1: التعريف: $A(K_1,K_2) = \frac{\langle K_1,K_2\rangle_F}{\|K_1\|_F\|K_2\|_F}$. الخطوة 2: بـ (27.3) و (26.3): $= \frac{\operatorname{tr}(K_1K_2)}{\sqrt{\operatorname{tr}(K_1^2)\operatorname{tr}(K_2^2)}} = \frac{\operatorname{tr}(K_1^\top K_2)}{\sqrt{\operatorname{tr}(K_1^\top K_1)\operatorname{tr}(K_2^\top K_2)}}$. الخطوة 3: هذا «جيب تمام» على فضاء المصفوفات $\Longrightarrow$ في $[-1,1]$ بكوشي–شفارتس (الفصل 2).

النتيجة: مقياس محاذاة في $[-1,1]$. الربط بالذكاء الاصطناعي: محاذاة النواة تُستخدم لمقارنة تمثيلات الشبكات العصبية CKA — Kernel Centered Alignment) وهي اليوم المعيار الذهبي لمقارنة تمثيلات النماذج.

مثال (3.3-14): آثر الهِسّية ومقياس «استواء» الأدنى

المعطيات: هِسّية عند نقطة تقارب: قيمها الذاتية $(0.5,\ 0.3,\ 0.05,\ 0.01)$؛ الخسارة عندها $\mathcal{L} = 0.02$. المطلوب: تقييم «استواء» الأدنى (flatness).

الحل: الخطوة 1: $\operatorname{tr}(H) = 0.5 + 0.3 + 0.05 + 0.01 = 0.86$. الخطوة 2: الأدنى «مستوٍ» إذا كان $\operatorname{tr}(H)$ صغيراً $\Longrightarrow$ الحساسية للاضطراب صغيرة. الخطوة 3: الانحناء المتوسط $\operatorname{tr}(H)/p = 0.86/4 = 0.215$. الخطوة 4: اضطراب بناظم $\varepsilon = 0.1$ $\Longrightarrow$ زيادة خسارة $\approx \frac{1}{2}\varepsilon^2\lambda_{\max} = 0.5\cdot 0.01\cdot 0.5 = 0.0025$.

النتيجة: أدنى مستوٍ نسبياً (حساسية 0025.0 لـ ϵ=1.0). الربط بالذكاء الاصطناعي: «الأدنى المستوي $\Longrightarrow$ تعميم أفضل» فرضية مدعومة تجريبياً؛ و $\operatorname{tr}(H)$ هو مقياسها القياسي (Sharpness-aware minimization يُقلّلها صراحةً).

مثال (3.3-15): تنظيم الآثر لتحسين الاستقرار

المعطيات: تدريب شبكة؛ نلاحظ تضخّماً في القيم المفردة لأوزان الطبقة: $\sigma = (8,\ 7,\ 6,\ 5) \Longrightarrow \|W\|_F^2 = 174$. المطلوب: أثر تنظيم $\lambda\operatorname{tr}(W^\top W)$ بـ $\lambda = 0.01$ على التدرّج.

الحل: الخطوة 1: حدّ التنظيم $= 0.01 \times 174 = 1.74$. الخطوة 2: التدرّج $= 2 \times 0.01 \times W = 0.02W$ $\Longrightarrow$ «انكماش» بنسبة 2% كل خطوة. الخطوة 3: الأثر الطيفي: كل القيم المفردة تتقلّص بالمعدّل ذاته $\Longrightarrow$ توزيع متساوٍ. الخطوة 4: بديل أكثر استهدافاً: التطبيع الطيفي يضبط $\sigma_{\max}$ فقط.

النتيجة: تنظيم متساوٍ على الطيف كله. الربط بالذكاء الاصطناعي: decay weight يضغط الطيف متساوياً؛ أما التطبيع الطيفي أو التنظيم النووي فيستهدفان بنية محدّدة — والاختيار يعتمد على الهدف (تعقيد أم متانة).

6.3.3 أخطاء شائعة

الخطأ	الصواب
تبديل العوامل عشوائياً داخل الآثر	الدورية = **تدوير** فقط (23.3)
$\operatorname{tr}(AB) = \operatorname{tr}(A)\operatorname{tr}(B)$	غير صحيح إطلاقاً
افتراض tr يحتاج مصفوفة مربّعة	$\operatorname{tr}(AB)$ معرَّف حتى لو كان A, B مستطيلتين (بشرط AB مربّعة)
حساب $\|A\|_F$ ببناء $A^\top A$	احسب مجموع المربعات مباشرة (أرخص وأدقّ)

الأهمية: «إذا تغيّر جزءٌ صغير من مصفوفتي، هل أعيد حساب المعكوس من الصفر؟» — وودبري تجيب: لا. وهذا الفرق بين $O(n^3)$ و $O(nk^2)$ هو ما يجعل العمليات الغاوسية والمرشّحات والتعلّم المتصل ممكناً على نطاق واسع.

1.4.3 الصياغة الرسمية

خصائص المعكوس:

$$(AB)^{-1} \;=\; B^{-1}A^{-1}, \qquad (A^\top)^{-1} \;=\; (A^{-1})^\top \tag{30.3}$$

متطابقة شيرمان–موريسون (تحديث رتبة-1):

$$\left(A + uv^\top\right)^{-1} \;=\; A^{-1} \;-\; \frac{A^{-1}u\,v^\top A^{-1}}{1 \;+\; v^\top A^{-1}u} \tag{31.3}$$

متطابقة وودبري (تحديث رتبة-k) — الصيغة العامة:

$$\left(A + UCV\right)^{-1} \;=\; A^{-1} \;-\; A^{-1}U\Big(C^{-1} + VA^{-1}U\Big)^{-1}VA^{-1} \tag{32.3}$$

الحالة الشائعة في التعلّم الآلي ($C = I$):

$$\left(A + UU^\top\right)^{-1} \;=\; A^{-1} \;-\; A^{-1}U\Big(I_k + U^\top A^{-1}U\Big)^{-1}U^\top A^{-1} \tag{33.3}$$

شرط الصحة:

$$A \text{ و } C \text{ قابلة للعكس } \left(C^{-1} + VA^{-1}U\right) \tag{34.3}$$

مبرهنة المحدّد المصاحبة:

$$\det\left(A + UCV\right) \;=\; \det(A)\,\det(C)\,\det\left(C^{-1} + VA^{-1}U\right) \tag{35.3}$$

عكس المصفوفة الكتلية:

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} = \begin{bmatrix} A^{-1} + A^{-1}B\,S^{-1}CA^{-1} & -A^{-1}B\,S^{-1} \\ -S^{-1}CA^{-1} & S^{-1} \end{bmatrix} \tag{36.3}$$

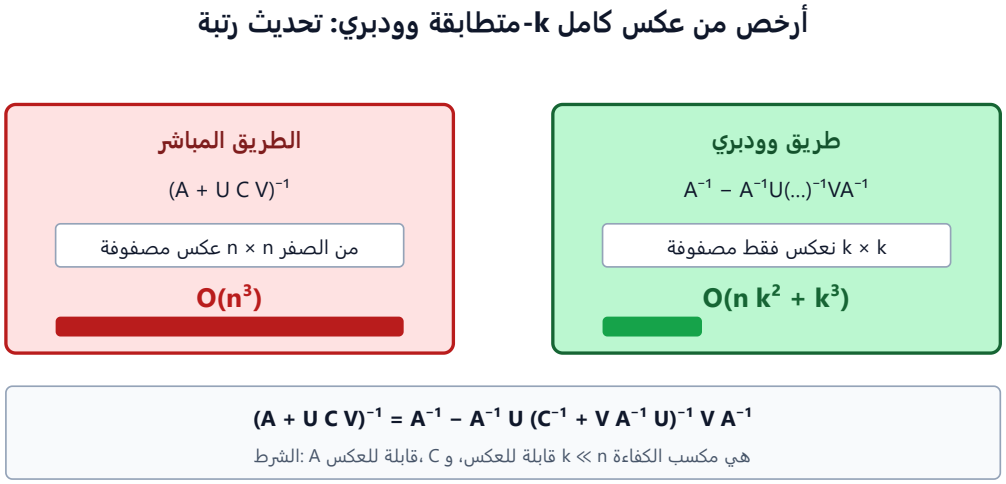
حيث $S = D - CA^{-1}B$ هو **مكمّل شور** (Schur complement). **التكلفة:**

$$\text{مباشر} : O(n^3) \qquad \text{وودبري} : O(nk^2 + k^3) \tag{37.3}$$

2.4.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
A^{-1}	المعكوس	$AA^{-1} = I$	موجود $\det A \neq 0 \iff$
$u,\ v$	متجهات التحديث	تحديث رتبة-1: $uv^\top$	(31.3)
$V \in \mathbb{R}^{k\times n}, U \in \mathbb{R}^{n\times k}$	عوامل التحديث	تحديث رتبة-k	(33.3) في $U = V^\top$
$C \in \mathbb{R}^{k\times k}$	مصفوفة التحديث	قابلة للعكس	غالباً I
$C^{-1} + VA^{-1}U$	«المعكوس المصغّر»	بحجم $k \times k$	مكسب الكفاءة كله هنا
S	مكمّل شور	$D - CA^{-1}B$	يظهر في كل مكان، (GP Newton)
k	رتبة التحديث	$k \ll n$	الفرضية الحاسمة
$\kappa(A)$	عدد الحالة	$\|A\|\|A^{-1}\|$	يقيس حساسية المعكوس

3.4.3 الشكل الهندسي



شكل ٤.٣: * وودبري

شكل (4.3): الطريق المباشر يعكس مصفوفة $n \times n$ من الصفر؛ طريق وودبري يعكس فقط مصفوفة $k \times k$ ويستخدم A^{-1} المخزَّنة مسبقاً.

4.4.3 البرهان

وودبري (32.3): نُثبت بضرب الطرف الأيمن في $(A + UCV)$ والحصول على I. ليكن $W = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$ ونُرمِز $M = (C^{-1} + VA^{-1}U)^{-1}$.

نحسب:

$$W(A+UCV) = \underbrace{A^{-1}A}_{I} + A^{-1}UCV - A^{-1}UMVA^{-1}A - A^{-1}UMVA^{-1}UCV$$

$$= I + A^{-1}U\Big[C - M - MVA^{-1}UC\Big]V$$

نُثبت أن المقدار بين القوسين [] يساوي صفراً. نلاحظ أن $VA^{-1}U = M^{-1} - \Longrightarrow M^{-1} = C^{-1} + VA^{-1}U$ C^{-1}، فنعوّض:

$$C - M - (M^{-1} - C^{-1})MC = C - M - (C - MC) = C - M - C + M = 0$$

إذن $W(A+UCV) = I \Longrightarrow W = (A+UCV)^{-1}$. (وبالمثل من اليسار.) ■

الحالة (31.3): تُستخرج من (32.3) بوضع $U = u$، $V = v^\top$، $C = 1 \Longrightarrow$ المقام $1 + v^\top A^{-1}u$ قياسي.

الكلّية (36.3): بحلّ النظام الكلّي بالتعويض: من الصف الثاني $Cx + Dy = 0 \Longrightarrow y = -D^{-1}Cx$... أو بحذف غاوس الكلّي؛ و S يظهر طبيعياً كـ «المتبقّي» بعد حذف B.

5.4.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-4.3): حلّ Ridge المغلق

المعطيات: $X \in \mathbb{R}^{100\times 20}$، نريد $\beta^\star = (X^\top X + \lambda I)^{-1}X^\top y$ بـ $\lambda = 1$. المطلوب: صيغة بديلة بوودبري وتكلفتها.

الحل: الخطوة 1: نُطبّق (33.3) مع $A = \lambda I$ و $U = X^\top$: $(X^\top X + \lambda I)^{-1} = \frac{1}{\lambda}I - \frac{1}{\lambda^2}X^\top\big(I_{100} + \frac{1}{\lambda}XX^\top\big)^{-1}X$. الخطوة 2: المصفوفة المعكوسة الآن بحجم 100×100 (عدد العيّنات) بدل $20 \times 20 \Longrightarrow$ هنا **أغلى**؛ فالقاعدة: استخدم الصيغة التي تعكس **الأصغر**. الخطوة 3: إذن هنا نعكس 20×20 مباشرة: $O(20^3) = 8000$. الخطوة 4: القاعدة العامة: إن كان $n < p$ استخدم الصيغة الأولية، وإن كان $p < n$ (حالة $p \gg n$) استخدم ووديري $\Longrightarrow$ $O(p^3)$ بدل $O(n^3)$.

النتيجة: توفير هائل في حالة $p \gg n$ (مثل الجينوم). الربط بالذكاء الاصطناعي: هذه «خدعة النواة المزدوجة» (kernel trick) بعينها: الصيغة المزدوجة تكلف $O(n^3)$ بغضّ النظر عن بُعد الميزات $\Longrightarrow$ وتسمح باستخدام ميزات لانهائية الأبعاد (kernels).

مثال (2-4.3): الانحدار في العمليات الغاوسية (GP)

المعطيات: $n = 5{,}000$ نقطة تدريب، نواة K، ضجيج $\sigma^2 = 0.01$. المطلوب: تكلفة عكس $(K + \sigma^2 I)$ وبديل ووديري.

الحل: الخطوة 1: مباشر: عكس $5000 \times 5000 \Longrightarrow O(n^3) = 1.25 \times 10^{11}$ دقائق. الخطوة 2: بتقريب منخفض الرتبة (Nyström) $K \approx UU^\top$ مع $U \in \mathbb{R}^{5000\times 200}$: الخطوة 3: بـ (33.3): $(\sigma^2 I + UU^\top)^{-1} =$

$O(nk^2) = 5000 \times 4 \times 10^4 = 200 \times 200$ ⟹. الخطوة 4: نعكس فقط $\frac{1}{\sigma^2} I - \frac{1}{\sigma^4} U \left(I_{200} + \frac{1}{\sigma^2} U^\top U\right)^{-1} U^\top$ ⟹ 2×10^8 أسرع بحوالي 600 مرة.

النتيجة: تسريع ×600 بتقريب رتبة 200. الربط بالذكاء الاصطناعي: هذه هي الفكرة الكامنة وراء كل طرق GP القابلة للتوسّع (Nyström، inducing points، SVGP) وكلها تطبيق لوودبري.

مثال (3-4.3): التعلّم المتصل (RLS) — وصول عيّنة جديدة

المعطيات: نموذج بمعكوس مصفوفة $P_t = (X_t^\top X_t + \lambda I)^{-1}$ محسوب مسبقاً، تصل عيّنة جديدة $x \in \mathbb{R}^p$. المطلوب: تحديث P دون إعادة الحساب.

الحل: الخطوة 1: التحديث: $P_{t+1} = (P_t^{-1} + xx^\top)^{-1}$. الخطوة 2: بشيرمان–موريسون (31.3) مع $u = v = x$: $P_{t+1} = P_t - \frac{P_t x x^\top P_t}{1 + x^\top P_t x}$. الخطوة 3: التكلفة: حساب $P_t x$ بـ $O(p^2)$ ثم جداء خارجي $O(p^2)$ ⟹ الإجمالي $O(p^2)$. الخطوة 4: مقابل $O(p^3)$ لإعادة الحساب الكامل ⟹ توفير بعامل p.

النتيجة: تحديث $O(p^2)$ بدل $O(p^3)$. الربط بالذكاء الاصطناعي: المربعات الصغرى المتكرّرة (RLS) أساسية في التعلّم المتصل والتحكم التكيّفي؛ وصيغة شيرمان–موريسون هي محرّكها.

مثال (4-4.3): تحديث رتبة-1 رقمياً

المعطيات: $A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$، $u = \binom{1}{1}$، $v = \binom{1}{0}$. المطلوب: حساب $(A + uv^\top)^{-1}$ طريقتين.

الحل: الخطوة 1: $uv^\top = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$ ⟹ $A + uv^\top = \begin{bmatrix} 3 & 0 \\ 1 & 3 \end{bmatrix}$ ⟹ المحدّد 9 ⟹ المعكوس $= \frac{1}{9} \begin{bmatrix} 3 & 0 \\ -1 & 3 \end{bmatrix}$. الخطوة 2: بوودبري: $A^{-1} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.333 \end{bmatrix}$، $A^{-1}u = \binom{0.5}{0.333}$، $v^\top A^{-1} u = 0.5$. الخطوة 3: المقام $1.5 = 1 + 0.5$ ⟹ التصحيح $\begin{bmatrix} 0.333 & 0 \\ 0.222 & 0 \end{bmatrix} = \frac{1}{1.5} \begin{bmatrix} 0.5 \\ 0.333 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix}$. الخطوة 4: نحسب $\begin{bmatrix} 0.333 & 0 \\ -0.111 & 0.333 \end{bmatrix}$. التصحيح: $A^{-1} = \operatorname{diag}(0.5, \frac{1}{3})$ ⟹ $A^{-1}u = \binom{0.5}{0.333}$، و $v^\top A^{-1} = \begin{bmatrix} 1 & 0 \end{bmatrix} \operatorname{diag}(0.5, \frac{1}{3}) = \begin{bmatrix} 0.5 & 0 \end{bmatrix}$، والمقام $1 + v^\top A^{-1} u = 1 + 0.5 = 1.5$. إذن التصحيح $= \frac{1}{1.5} \binom{0.5}{0.333} \begin{bmatrix} 0.5 & 0 \end{bmatrix} = \frac{1}{1.5} \begin{bmatrix} 0.25 & 0 \\ 0.1667 & 0 \end{bmatrix} = \begin{bmatrix} 0.1667 & 0 \\ 0.1111 & 0 \end{bmatrix}$. الخطوة 5: الناتج $\begin{bmatrix} 0.3333 & 0 \\ -0.1111 & 0.3333 \end{bmatrix} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.333 \end{bmatrix} - \begin{bmatrix} 0.1667 & 0 \\ 0.1111 & 0 \end{bmatrix}$. الخطوة 6:

تحقق: نضرب في $\begin{bmatrix} 3 & 0 \\ 1 & 3 \end{bmatrix}$ ⟹ الصف 1: $(1, 0)$؛ الصف 2: $(0, 1)$ ✓ **يطابق الحلّ المباشر تماماً.**

النتيجة: تطابق تام ✓. الربط بالذكاء الاصطناعي: دائماً تحقق من وودبري على مثال 2×2 قبل الاعتماد عليها في كود إنتاجي؛ أكثر الأخطاء شيوعاً الخلط بين $v^\top A^{-1}$ و $A^{-1} v$.

مثال (5-4.3): مرشّح كالمان بصيغة المعلومات

المعطيات: تحديث كالمان القياسي يحدّث التغاير P بحجم $n \times n$؛ الصيغة البديلة تحدّث P^{-1}. المطلوب: متى تكون صيغة المعلومات أفضل؟

الحل: الخطوة 1: في صيغة المعلومات: التحديث $P^{-1} \leftarrow P^{-1} + H^\top R^{-1} H$ (جمع بسيط). الخطوة 2: التكلفة $O(n^2 m)$ مقابل $O(n^3)$ للصيغة القياسية. الخطوة 3: الأفضل عندما يكون عدد القياسات n $\gg$ m (قليل من المستشعرات، حالة كثيرة). الخطوة 4: وهذا تطبيق مباشر لـ (32.3) مع $A = P^{-1}$ و $U = H^\top$ و $C = R^{-1}$ و $V = H$.

النتيجة: $O(n^2 m)$ بدل $O(n^3)$ حين $m \ll n$. الربط بالذكاء الاصطناعي: صيغة المعلومات تُستخدم في SLAM متعدد الروبوتات وفي دمج مستشعرات القيادة الذاتية، وهي تمكين مباشر لوودبري.

مثال (6-4.3): غاوس-نيوتن وليفنبرغ-ماركوارت

المعطيات: نريد حلّ $J^\top J\,\Delta = -J^\top r$ مع $J \in \mathbb{R}^{N \times p}$ (يعقوبي المخلفات). المطلوب: صيغة ليفنبرغ وتحديث منخفض الرتبة.

الحل: الخطوة 1: المخاطرة: $J^\top J$ قد تكون منفردة $\Longrightarrow$ نضيف λI: $(J^\top J + \lambda I)\Delta = -J^\top r$. الخطوة 2: بوودبري مع $A = \lambda I$، $U = J^\top$: $\Delta = -\left[\frac{1}{\lambda} I - \frac{1}{\lambda^2} J^\top \left(I_N + \frac{1}{\lambda} J J^\top\right)^{-1} J\right] J^\top r$. الخطوة 3: نُبسّط بالدورية: $\Delta = -\frac{1}{\lambda}\left[I - J^\top \left(\lambda I_N + J J^\top\right)^{-1} J\right] J^\top r$. الخطوة 4: مناسبة حين $p \gg N$ $\Longrightarrow$ نعكس $N \times N$.

النتيجة: خطوة نيوتن قابلة للحساب في فضاء المخلفات. الربط بالذكاء الاصطناعي: هذا هو أساس طرق الدرجة الثانية في التعلّم العميق (K-FAC، Gauss-Newton؛ وكلها تعتمد على تحويل المعكوس الكبير إلى معكوس صغير (approximations).

مثال (7-4.3): التحقّق المتقابل بترك-واحدة-خارجاً (LOO-CV) لـ Ridge

المعطيات: نموذج Ridge مدرب على $n = 1000$ عيّنة؛ نريد خطأ LOO لكل عيّنة. المطلوب: هل نُعيد التدريب 1000 مرة؟

الحل: الخطوة 1: **لا.** توجد صيغة مغلقة: مؤثّر القبعة $H_\lambda = X(X^\top X + \lambda I)^{-1} X^\top$. الخطوة 2: خطأ LOO للعيّنة i: $e_i^{\text{loo}} = \frac{y_i - \hat{y}_i}{1 - H_{ii}}$. الخطوة 3: إذن نحتاج فقط **قطر** H_λ $\Longrightarrow$ حساب واحد لا ألف. الخطوة 4: وقطر H_λ يُحسب من $X(X^\top X + \lambda I)^{-1} X^\top$ دون بناء المصفوفة كاملة: $H_{ii} = x_i^\top (X^\top X + \lambda I)^{-1} x_i$.

النتيجة: LOO بتكلفة تدريب واحد. الربط بالذكاء الاصطناعي: هذه إحدى «المعجزات» العملية للنماذج الخطية: التحقّق المتقابل الدقيق شبه مجاني، ولا مثيل لها في الشبكات العميقة.

مثال (8-4.3): تحديث متصل لتغاير الميزات (incremental PCA)

المعطيات: مصفوفة تغاير محدَّثة: $C_{t+1} = \frac{t}{t+1} C_t + \frac{1}{t+1} x x^\top$؛ نحتاج C_{t+1}^{-1} لتبييض الميزات. المطلوب: تحديث المعكوس.

الحل: الخطوة 1: نُعيد الكتابة: $C_{t+1} = \alpha C_t + \beta x x^\top$ مع $\alpha = \frac{t}{t+1}$، $\beta = \frac{1}{t+1}$. الخطوة 2: نُخرج αC_t: $C_{t+1} = \alpha\left(C_t + \frac{\beta}{\alpha} x x^\top\right)$. الخطوة 3: بشيرمان-موريسون: $C_{t+1}^{-1} = \frac{1}{\alpha}\left[C_t^{-1} - \frac{C_t^{-1} x\, x^\top C_t^{-1}}{\frac{\alpha}{\beta} + x^\top C_t^{-1} x}\right]$. الخطوة 4: التكلفة

$O(p^2)$ لكل تحديث بدل $O(p^3)$.

النتيجة: تبييض متصل بتكلفة تربيعية. الربط بالذكاء الاصطناعي: في التدريب المتدفّق (streaming) لا يمكن إعادة حساب إحصاءات التطبيع؛ وتحديثات شيرمان–موريسون هي الحلّ القياسي.

مثال (3.4-9): تحديث نظام توصية بوصول مستخدم جديد

المعطيات: نظام بمعكوس مدمج $M^{-1} \in \mathbb{R}^{1000\times 1000}$؛ مستخدم جديد يضيف 5 تفاعلات $\Longrightarrow$ تحديث رتبة-5. المطلوب: تكلفة التحديث مقابل إعادة الحساب.

الحل: الخطوة 1: إعادة الحساب: $1000^3 = 10^9$ عملية. الخطوة 2: بوودبري مع $k = 5$: $nk^2 + k^3 = 1000 \cdot 25{+}125 = 25{,}125$. الخطوة 3: النسبة: $\frac{10^9}{2.5\times 10^4} = 40{,}000$ $\Longrightarrow$ تسريع بأربع مراتب. الخطوة 4: الشرط: أن نحتفظ بـ M^{-1} مخزَّنة $\Longrightarrow$ ذاكرة $O(n^2)$ مقابل وقت $O(n^3)$.

النتيجة: تسريع ×40,000. الربط بالذكاء الاصطناعي: أنظمة التوصية الحقيقية تستقبل آلاف التفاعلات في الثانية $\Longrightarrow$ بدون تحديثات رتبة-منخفضة يستحيل التحديث الآني.

مثال (3.4-10): خطوة نيوتن مع تقريب هِسّية منخفض الرتبة

المعطيات: هِسّية مقدَّرة $H \approx D + UU^\top$ مع D قطرية موجبة و $U \in \mathbb{R}^{p\times 10}$، $p = 10^6$. المطلوب: حساب $H^{-1}g$.

الحل: الخطوة 1: عكس D مباشرة: $O(p)$ (قطرية). الخطوة 2: بـ (3.3.3): $H^{-1}g = D^{-1}g - D^{-1}U\big(I_{10} + U^\top D^{-1}U\big)^{-1}U^\top D^{-1}g$. الخطوة 3: التكلفة: جداءات مصفوفة-متجه $O(pk) = 10 \times 10$ + عكس 10^7. الخطوة 4: مقابل $O(p^3) = 10^{18}$ المستحيل $\Longrightarrow$ فرق شاسع.

النتيجة: من مستحيل إلى 10^7 عملية. الربط بالذكاء الاصطناعي: هذا بالضبط ما تفعله طرق التحسين من الدرجة الثانية العملية، (L-BFGS، K-FAC، Shampoo): تقريب منخفض الرتبة + وودبري بدل الهِسّية الكاملة.

مثال (3.4-11): إضافة ميزة جديدة للانحدار

المعطيات: نموذج بـ $p = 20$ ميزة ومعكوس $P = (X^\top X)^{-1}$ محسوب؛ نضيف ميزة جديدة $z \in \mathbb{R}^n$. المطلوب: معكوس المصفوفة الموسّعة.

الحل: الخطوة 1: المصفوفة الموسّعة كتلياً: $\begin{bmatrix} X^\top X & X^\top z \\ z^\top X & z^\top z \end{bmatrix}$ $\Longrightarrow$ نستخدم (3.3.6). الخطوة 2: مكمّل شور $S = z^\top z - z^\top X\, P\, X^\top z$ (قياسي!). الخطوة 3: S هو «التباين المتبقّي للميزة الجديدة بعد إسقاطها على الميزات الحالية». الخطوة 4: المعكوس الكلّي يعطي المعاملات المحدَّثة دون إعادة حساب كامل.

النتيجة: تحديث $O(np{+}p^2)$ بدل $O(p^3)$. الربط بالذكاء الاصطناعي: مكمّل شور يظهر في اختيار الميزات المتسلسل: S صغير $\Longrightarrow$ الميزة الجديدة متكرّرة $\Longrightarrow$ لا فائدة منها.

مثال (3.4.12): المتانة الخصامية و $(I+uv^\top)^{-1}$

المعطيات: اضطراب خصامي على الأوزان: $W \to W + uv^\top$ برتبة 1، نريد أثره على المخرج. المطلوب: هل يمكن حساب الأثر تحليلياً؟

الحل: الخطوة 1: التغيّر في المخرج: $\Delta y = uv^\top x = u\,(v^\top x)$ $\Longrightarrow$ ذو رتبة 1 وسهل الحساب تماماً. الخطوة 2: لأجل «المقلوب» (مثل تدفق عكسي أو طبقة قابلة للعكس): بشيرمان–موريسون يتغيّر المعكوس بمركّبة رتبة-1. الخطوة 3: $\Longrightarrow$ حساب تأثير أي اضطراب رتبة-1 على «عكس الشبكة» بتكلفة $O(n)$ لا $O(n^3)$. الخطوة 4: الأهمية: شهادات المتانة غالباً تحسب أسوأ حالة على كرة $\Longrightarrow$ والاضطراب الأسوأ رتبته 1 (من نظرية القيم المفردة).

النتيجة: الاضطراب الأسوأ رتبة-1 $\Longrightarrow$ تحليل رخيص. الربط بالذكاء الاصطناعي: هذا هو أساس «التدريب الخصامي الرخيص» (Fast Gradient Sign Method) وتحليلاته): أسوأ اضطراب داخل كرة L_∞ ذو بنية بسيطة قابلة للحساب المغلق.

مثال (3.4.13): تحديث إحصاءات التطبيع الدفعي

المعطيات: إحصاءات جارية: μ_t و σ_t^2؛ تصل دفعة جديدة بمتوسط μ_b وتباين σ_b^2 وحجم m. المطلوب: صيغة التحديث (ولماذا نحتاج المعكوس أحياناً).

الحل: الخطوة 1: بالزخم: $\mu_{t+1} = (1-\alpha)\mu_t + \alpha\mu_b$ مع $\alpha = m/(N+m)$. الخطوة 2: التباين: $\sigma^2_{t+1} = (1-\alpha)\sigma_t^2 + \alpha\sigma_b^2 + \alpha(1-\alpha)(\mu_t-\mu_b)^2$ (مصطلح تصحيح). الخطوة 3: في التبييض الكامل (ZCA) نحتاج $\Sigma^{-1/2}$ لا مجرد σ $\Longrightarrow$ نحدّث المعكوس بشيرمان–موريسون. الخطوة 4: التكلفة: $O(p^2)$ لكل دفعة بدل $O(p^3)$.

النتيجة: تحديث متصل للتبييض. الربط بالذكاء الاصطناعي: في التدريب الموزّع على آلاف الدفعات، إعادة حساب إحصاءات التبييض مكلفة؛ والتحديثات الرتبية هي الحلّ العملي.

مثال (3.4.14): نيوتن الموزّع بعكس الكتل

المعطيات: هِسّية موزّعة كتلياً: $H = \begin{bmatrix} H_{11} & H_{12} \\ H_{21} & H_{22} \end{bmatrix}$ حيث كل كتلة على عقدة مختلفة. المطلوب: كيف نحسب $H^{-1}g$ دون تجميع الكل؟

الحل: الخطوة 1: بـ (3.6.36) نحتاج H_{11}^{-1} و S^{-1} حيث $S = H_{22} - H_{21}H_{11}^{-1}H_{12}$. الخطوة 2: كل عقدة تعكس كتلتها المحلية، ونحتاج منتجاً واحداً $H_{21}H_{11}^{-1}H_{12}$ للتنسيق. الخطوة 3: حجم التبادل: $O(k^2)$ حيث k حجم الكتلة المشتركة $\Longrightarrow$ صغير. الخطوة 4: الشرط: H_{11} قابلة للعكس (وهو مضمون بتنظيم ليفنبرغ).

النتيجة: عكس موزّع بتبادل ضئيل. الربط بالذكاء الاصطناعي: هذه البنية الكتلية هي أساس كل خوارزميات التحسين الموزّعة من الدرجة الثانية (Distributed Newton، DANE، DiSCO).

مثال (3.4.15): التوزيع الشرطي الغاوسي بعكس الكتل

المعطيات: $(X_1, X_2) \sim \mathcal{N}\left(0,\ \begin{bmatrix}\Sigma_{11} & \Sigma_{12}\\ \Sigma_{21} & \Sigma_{22}\end{bmatrix}\right)$ بـ $\Sigma_{11} = 4$، $\Sigma_{22} = 9$، $\Sigma_{12} = 3$. المطلوب: $X_1 \mid X_2 = 2$.

الحل: الخطوة 1: نستخدم (36.3) لحساب معكوس التغاير (مصفوفة الدقة $K = \Sigma^{-1}$). الخطوة 2: مكمّل شور $S = 9 - 3 \cdot \frac{1}{4} \cdot 3 = 9 - 2.25 = 6.75$. الخطوة 3: المتوسط الشرطي: $\mathbb{E}[X_1 \mid X_2 = 2] = \Sigma_{12}\Sigma_{22}^{-1} \cdot 2 = \frac{3}{9} \cdot 2 = 0.667$. الخطوة 4: التباين الشرطي: $\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = 4 - \frac{9}{9} = 3$.

النتيجة: $X_1 \mid X_2 = 2 \sim \mathcal{N}(0.667,\ 3)$. الربط بالذكاء الاصطناعي: هذه هي بالضبط صيغة التنبؤ في العمليات الغاوسية، ومكمّل شور S هو «المعلومات الجديدة» التي تضيفها الملاحظة.

6.4.3 أخطاء شائعة

الخطأ	الصواب
عكس مصفوفة صراحةً لحلّ $Ax = b$	استخدم solve (LU/Cholesky) — أرخص وأدقّ
تبديل ترتيب العوامل في وودبري	U يساراً و V يميناً؛ الترتيب حاسم
استخدام وودبري عند $k \approx n$	لا مكسب؛ بل عبء إضافي
تجاهل شرط (34.3)	قد يكون $C^{-1} + VA^{-1}U$ منفرداً رغم أن A, C قابلتان للعكس
حساب det للتحقق من العكس	استخدم عدد الحالة أو القيم المفردة

الأهمية: أي تحويل خطي يمكن فصله إلى «**شكل**» (تدوير أو انعكاس، بلا تغيير حجم) و«**حجم**» (تمدد على محاور متعامدة). هذا الفصل بين الشكل والحجم هو ما تستخدمه تطبيع الأوزان، ومحاذاة النماذج، والتحسين على متشعّب المصفوفات المتعامدة.

1.5.3 الصياغة الرسمية

التفكك القطبي الأيمن: لكل $A \in \mathbb{R}^{m \times n}$ $(m \geq n)$ يوجد تفكيك:

$$A = U\,P, \qquad U^\top U = I_n, \qquad P = \left(A^\top A\right)^{1/2} \succeq 0 \tag{38.3}$$

التفكك القطبي الأيسر:

$$A = P'\,U, \qquad P' = \left(AA^\top\right)^{1/2} \succeq 0 \tag{39.3}$$

الوحدانية (عند رتبة كاملة عمودية): إذا كان $\operatorname{rank}(A) = n$ فإن:

$$P \text{ موجبة التحديد وحيدة} \qquad U = A\,(A^\top A)^{-1/2} \text{ وحيد,} \tag{40.3}$$

العلاقة بـ SVD: إذا كان $A = W\Sigma V^\top$ فإن:

$$U = WV^\top, \qquad P = V\Sigma V^\top \tag{41.3}$$

خاصية «أقرب مصفوفة متعامدة» (مسألة بروكروستس المتعامدة):

$$U = \underset{Q:\ Q^\top Q = I}{\arg\min} \|A - Q\|_F \tag{42.3}$$

إشارة المحدّد تحدّد نوع «الشكل»:

$$\det(U) = -1 \iff \text{انعكاس} \qquad \det(U) = +1 \iff \text{تدوير (يحفظ الاتجاه)}, \tag{43.3}$$

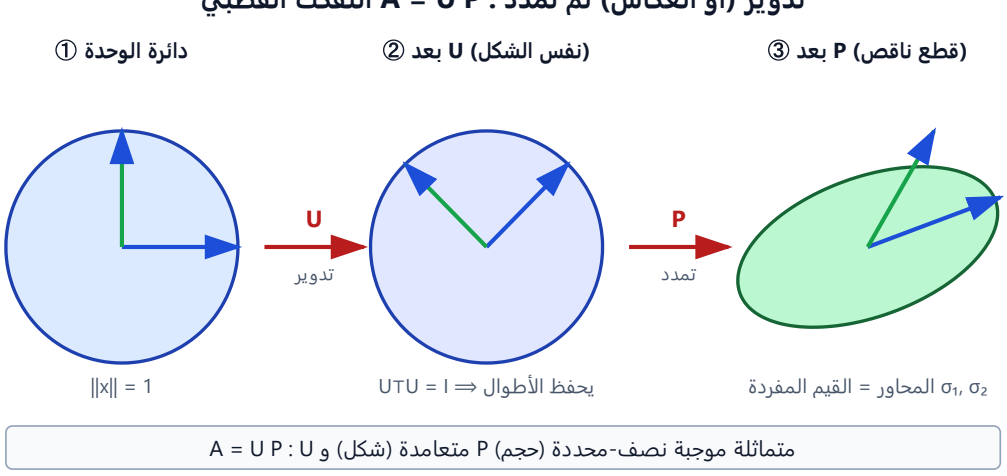
تصنيف التحويلات في $\mathbb{R}^2$:

$$A = \underbrace{R_\theta}_{\text{تدوير}} \underbrace{\begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix}}_{\text{تمدد}} \underbrace{R_\phi^\top}_{\text{تدوير}} \tag{44.3}$$

2.5.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
U	العامل المتعامد	$U^\top U = I$، يحفظ الأطوال والزوايا	«الشكل»
P	العامل الموجب	متماثلة موجبة نصف-محددة	«الحجم»
$A^{1/2}$	الجذر التربيعي الماتريسي	B بحيث $B^2 = A$، موجبة	يُحسب عبر القيم الذاتية/المفردة
$\succeq 0$	موجبة نصف-محددة	كل القيم الذاتية ≥ 0	—
$W,\ V$	العاملان المتعامدان في SVD	أعمدة مفردة يساراً ويميناً	الفصل 4
Σ	مصفوفة القيم المفردة	قطرية غير سالبة	—
$\|\cdot\|_F$	ناظم فروبنيوس	في (42.3)	—
$\arg\min$ على المتعامدات	إسقاط على متشعب Stiefel	retraction» «polar	التحسين الهندسي
$\det U$	إشارة التحويل	$+1$ دوران، -1 انعكاس	(43.3)

3.5.3 الشكل الهندسي



شكل ٥.٣: *
التفكك القطبي

شكل (5.3): دائرة الوحدة ⟶ (تدوير U: نفس الشكل) ⟶ (تمدد P: قطع ناقص محاوره القيم المفردة).

4.5.3 البرهان

الوجود: ليكن $A = W\Sigma V^\top$ تحليل SVD (الفصل 4). نُعرّف $U = WV^\top$ و $P = V\Sigma V^\top$. نتحقق:

$$UP = (WV^\top)(V\Sigma V^\top) = W\Sigma V^\top = A$$

و $U^\top U = VW^\top WV^\top = VV^\top = I_n$؛ و $P = V\Sigma V^\top$ متماثلة بقيم ذاتية = القيم المفردة $\geq 0 \implies$ موجبة نصف-محددة ✓.

الوحدانية عند الرتبة الكاملة: لو وُجد $A = U_1P_1 = U_2P_2$، فـ $A^\top A = P_1U_1^\top U_1P_1 = P_1^2$ وبالمثل $= P_2^2$. وبما أن للجذر التربيعي الموجب وحيداً $\implies P =: P_1 = P_2$. ثم $U_1P = U_2P$؛ وبما أن P قابلة للعكس (الرتبة كاملة $\implies$ كل $\sigma_i > 0$) $\implies U_1 = U_2$.

(42.3) أقرب مصفوفة متعامدة: نُوسّع بمساواة الآثر:

$$\|A - Q\|_F^2 = \operatorname{tr}(A^\top A) + \operatorname{tr}(Q^\top Q) - 2\operatorname{tr}(Q^\top A) = \|A\|_F^2 + n - 2\operatorname{tr}(Q^\top A)$$

إذن التصغير يكافئ **تعظيم** $\operatorname{tr}(Q^\top A)$. وبكتابة $A = UP$: $\operatorname{tr}(Q^\top UP)$. وبمتراجحة فون-نيومان للآثر (تُثبت بالقيم المفردة وتعميم كوشي–شفارتس):

$$\operatorname{tr}(Q^\top UP) \leq \sum_i \sigma_i(P)$$

والتساوي يتحقّق عند $Q = U \implies$ هي الأقرب. ■

5.5.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (5.3-1): تطبيع الأوزان (Weight Normalization)

المعطيات: طبقة $y = Wx$، نعيد كتابة $W = g\frac{V}{\|V\|_F}$. المطلوب: العلاقة بالتفكك القطبي.

الحل: الخطوة 1: $\frac{V}{\|V\|_F}$ ليست متعامدة بالضرورة (التطبيع بناظم فروبنيوس لا بالتفكك القطبي). الخطوة 2: البديل الأقوى: نأخذ العامل المتعامد U من التفكك القطبي لـ V: $V = UP$، ونستخدم $W = gU$. الخطوة 3: حينئذٍ $\|Wx\| = g\|x\| \implies$ التحويل **تشابه كامل** بعامل $g \implies$ لا تمدد تفاضلي. الخطوة 4: الفائدة: فصل «الحجم» g عن «الاتجاه» $U \implies$ تحسين أسهل واستقرار أفضل.

النتيجة: فصل الحجم عن الاتجاه $\implies$ استقرار. الربط بالذكاء الاصطناعي: تطبيع الأوزان (Salimans & Kingma 2016) والتطبيع الطيفي يفعلان هذا بالضبط، وكلاهما أثبت تحسيناً في استقرار GAN والتدريب العميق.

مثال (5.3-2): تدوير التضمينات (Orthogonal Procrustes) بين نموذجين

المعطيات: تضمينات نموذج قديم $A \in \mathbb{R}^{N\times d}$ ونموذج جديد $B \in \mathbb{R}^{N\times d}$ لنفس الكلمات. المطلوب: مصفوفة تدوير R تقارب AR بـ B.

الحل: الخطوة 1: نُشكّل $M = A^\top B \in \mathbb{R}^{d\times d}$. الخطوة 2: التفكك القطبي لـ M: $M = UP \Longrightarrow$ الحلّ الأمثل $R^\star = U$. الخطوة 3: التفسير: U هي «أقرب مصفوفة متعامدة» إلى M بـ (42.3). الخطوة 4: الخطأ المتبقي: $\|M\|_F^2 - \sum_i \sigma_i(M) \Longrightarrow$ صفر إن كانت M متعامدة أصلاً.

النتيجة: $R^\star$ العامل المتعامد لـ $A^\top B$. الربط بالذكاء الاصطناعي: هذه هي خوارزمية محاذاة النماذج (model stitching / merging) ومحاذاة التضمينات عبر اللغات، وتُستخدم اليوم لدمج أوزان نماذج مختلفة (model soup).

مثال (3-5.3): تحليل طبقة: كم تدور وكم تمدد؟

المعطيات: مصفوفة طبقة W بقيم مفردة $(5,\ 4,\ 0.5)$؛ العامل المتعامد U بـ $\det U = +1$. المطلوب: وصف سلوك الطبقة.

الحل: الخطوة 1: «الحجم»: التمدد على ثلاثة محاور بمعاملات $5,\ 4,\ 0.5$. الخطوة 2: «الشكل»: $\det U = +1 \Longrightarrow$ تدوير (لا انعكاس). الخطوة 3: نسبة الاستطالة $= \sigma_1/\sigma_3 = 5/0.5 = 10 \Longrightarrow$ الطبقة «تسطّح» الفضاء بقوة في اتجاه واحد. الخطوة 4: عدد الحالة $= 10 \Longrightarrow$ حساسية متوسطة للمدخلات.

النتيجة: تدوير + تمدد غير متساوٍ بنسبة 10:1. الربط بالذكاء الاصطناعي: نسبة الاستطالة (condition number) مؤشر عملي على صعوبة تحسين الطبقة؛ ومنه تقنيات التطبيع الطيفي التي تضبط σ_1 فقط.

مثال (4-5.3): تهيئة متعامدة عبر العامل القطبي

المعطيات: مصفوفة عشوائية غاوسية $G \in \mathbb{R}^{512\times 512}$. المطلوب: تحويلها إلى مصفوفة متعامدة بأفضل طريقة.

الحل: الخطوة 1: نحسب التفكك القطبي $G = UP$. الخطوة 2: نأخذ $W = U \Longrightarrow \|W\|_{\text{op}} = 1$ وكل القيم المفردة $= 1$. الخطوة 3: هذا «إسقاط على متشعّب المصفوفات المتعامدة» (بـ 42.3) $\Longrightarrow$ الأقرب إلى G. الخطوة 4: مقارنة بـ QR: يعطي متعامدة أيضاً لكن ليس «الأقرب» $\Longrightarrow$ القطبي أفضل لتطبيع التوزيع العشوائي.

النتيجة: $W = U \Longrightarrow$ تهيئة تحفظ الطاقة وتوزيعاً أقرب للأصل. الربط بالذكاء الاصطناعي: التهيئة المتعامدة (Saxe et al.) تُطبَّق فعلياً عبر القطبي/SVD وهي العلاج القياسي لتلاشي/انفجار التدرّج في الشبكات العميقة والمتكرّرة.

مثال (5-5.3): الضغط: فصل الاتجاه عن الحجم

المعطيات: مصفوفة أوزان $W \in \mathbb{R}^{1024\times 1024}$، العامل المتعامد U (مصفوفة متعامدة) و P (متماثلة موجبة). المطلوب: هل يمكن ضغط U بسهولة؟

الحل: الخطوة 1: U مصفوفة متعامدة $\Longrightarrow$ كل قيمها المفردة $= 1 \Longrightarrow$ **لا يمكن** تقريبها برتبة منخفضة (الطيف مسطّح تماماً). الخطوة 2: أما P فمتماثلة $\Longrightarrow$ قيمها الذاتية قد تكون متناثرة $\Longrightarrow$ قابلة للاقتطاع. الخطوة 3: $\Longrightarrow$ يجب ضغط P فقط (أو ضغط W كاملاً بـ SVD). الخطوة 4: تخزين U يحتاج بنية خاصة (Householder أو Givens) لا مصفوفة كثيفة.

النتيجة: الضغط يعمل على P لا U. الربط بالذكاء الاصطناعي: هذا يفسّر لماذا ضغط الأوزان بـ SVD فعّال: الطيف الحقيقي للطبقات المدربة غير متساوٍ (مركّز في P) لا مسطّح.

مثال (3.5-6): انعكاس أم تدوير؟ فحص بالاتجاه

المعطيات: تحويل ثنائي الأبعاد $A = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$ (انعكاس حول محور x). المطلوب: تفكيكه القطبي ونوعه.

الحل: الخطوة 1: $\det A = -1 \implies$ انعكاس. الخطوة 2: $A^\top A = I \implies P = I^{1/2} = I$ (لا تمدد!). الخطوة 3: إذن $U = A$ نفسه $\implies A = U \cdot I$: انعكاس خالص بلا تمدد. الخطوة 4: تحقق بـ (3.43): $\det U = -1 \implies$ انعكاس ✓.

النتيجة: انعكاس صرف (لا يغيّر الأحجام). الربط بالذكاء الاصطناعي: المصفوفات ذات $\det = -1$ تظهر في تحويلات التناظر المرآتي في زيادة البيانات، ومعرفة ذلك تمنع أخطاء «الصور المقلوبة» في التدريب.

مثال (3.5-7): ثبات التحويل في زيادة البيانات

المعطيات: زيادة بيانات بمصفوفة A، نريد أن تكون «آمنة» أي لا تغيّر حجم الميزات بشدة. المطلوب: شرط على A.

الحل: الخطوة 1: نُفكّك $A = UP$. الخطوة 2: الشرط: $\|A\|_{\text{op}} = \sigma_1(P) \approx 1 \implies$ لا تمدد. الخطوة 3: $\implies$ نتحقّق أن كل القيم المفردة قريبة من 1 $\implies P \approx I$ و $A \approx U$ (تحويل هندسي صرف). الخطوة 4: مثال: الدوران يحقق ذلك تماماً، أما «القصّ» (shear) فلا.

النتيجة: زيادة آمنة $\iff$ القيم المفردة ≈ 1. الربط بالذكاء الاصطناعي: زيادة البيانات الهندسية «الآمنة» تُبقي على توزيع ناظم الميزات $\implies$ لا تحتاج إعادة معايرة التطبيع.

مثال (3.5-8): إسقاط على متشعّب (Polar Stiefel Retraction)

المعطيات: مصفوفة $X \in \mathbb{R}^{512\times 64}$ فقدت تعامدها بعد خطوة تدرّج، نريد إعادتها للمتشعّب. المطلوب: طريقة الإعادة (retraction).

الحل: الخطوة 1: التفكك القطبي $X = UP$. الخطوة 2: الإسقاط (retraction): $X_{\text{new}} = U \implies$ أقرب مصفوفة متعامدة بـ (3.42). الخطوة 3: التكلفة: SVD لمصفوفة $64 \times 512 \implies O(512 \cdot 64^2)$ مقبول. الخطوة 4: هذه هي «retraction polar» القياسية في التحسين على المتشعّبات (الفصل 24).

النتيجة: إعادة التعامد بـ polar retraction. الربط بالذكاء الاصطناعي: التحسين على متشعّب المصفوفات المتعامدة (orthogonal) يُستخدم لفرض قيود صارمة في الشبكات spectral RNN، Riemannian normalization، Adam).

مثال (3.5-9): تشخيص انهيار الطبقة

المعطيات: طبقة بقيم مفردة $(100, 0.1, 0.09, 0.08)$ بعد التدريب. المطلوب: تشخيص الحالة بالتفكك القطبي.

الحل: الخطوة 1: P لها قيمة ذاتية مهيمنة 100 والباقي $\approx 1.0 \implies$ نسبة 1000:1. الخطوة 2: التفسير الهندسي:

الطبقة «تبسط» الفضاء على مستوٍ واحد تقريباً $\Longrightarrow$ انهيار الأبعاد. الخطوة 3: العامل المتعامد U سليم (متعامد) $\Longrightarrow$ المشكلة في «الحجم» لا «الشكل». الخطوة 4: العلاج: تنظيم طيفي أو تطبيع طبقي.

النتيجة: انهيار في P لا في U. الربط بالذكاء الاصطناعي: هذا التشخيص التفريقي (شكل أم حجم؟) يوجّه العلاج: مشاكل P $\Longrightarrow$ تنظيم طيفي؛ مشاكل U $\Longrightarrow$ إعادة تهيئة/تعامد.

مثال (5.3-10): حفظ الأطوال في RoPE وطبقات متعامدة

المعطيات: طبقة $f(x) = Ux$ بـ U متعامدة، مدخل $\|x\| = 7$. المطلوب: ناظم المخرج والتدرّج العكسي.

الحل: الخطوة 1: $\|Ux\| = 7 \Longrightarrow \|Ux\|^2 = x^\top U^\top U x = x^\top x = 49$. الخطوة 2: التدرّج العكسي: $\nabla_x = U^\top g \Longrightarrow \|\nabla_x\| = \|U^\top g\| = \|g\|$ **لا تلاشٍ ولا انفجار**. الخطوة 3: هذا هو السبب الجوهري لاستخدام المصفوفات المتعامدة في RNN و ResNet. الخطوة 4: في التفكك القطبي: $A = UP \Longrightarrow$ التمدد يأتي حصرياً من P.

النتيجة: حفظ كامل للأطوال في الأمام والخلف. الربط بالذكاء الاصطناعي: هذه الخاصية هي المبرّر الرياضي العميق لكل تقنيات «التعامد» في التعلّم العميق الحديث (من RNN orthogonal إلى Muon optimizer).

مثال (5.3-11): تصنيف تحويل ثنائي الأبعاد بالقيم المفردة

المعطيات: $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$. المطلوب: وصف هندسي كامل.

الحل: الخطوة 1: A متماثلة $\Longrightarrow A^\top A = A^2 \Longrightarrow$ القيم المفردة = القيم الذاتية $3 = 3$ و 1. الخطوة 2: القيم الموجبة $\Longrightarrow U = I$ (لا تدوير، $P = A$). الخطوة 3: المتجهات الذاتية: $\frac{1}{\sqrt{2}}(1,1)$ بقيمة 3، و $\frac{1}{\sqrt{2}}(1,-1)$ بقيمة 1. الخطوة 4: الوصف: تمدد ×3 على القطر الرئيسي و ×1 على القطر الثانوي $\Longrightarrow$ تحويل «إهليلجي» بلا تدوير.

النتيجة: تمدد محوري بلا تدوير ($\det = 3 > 0$). الربط بالذكاء الاصطناعي: فهم التحويلات بهذه الطريقة يجعل تحليل «ماذا تعلّمت الطبقة؟» مسألة قراءة للقيم المفردة واتجاهاتها.

مثال (5.3-12): دمج نماذج (Model Merging) بمحاذاة متعامدة

المعطيات: نموذجان مدربان من نفس التهيئة على بيانات مختلفة: أوزان $W_1, W_2 \in \mathbb{R}^{d \times d}$. المطلوب: هل يمكن جمعهما مباشرة؟

الحل: الخطوة 1: الشبكات لها تناظر تبديلي (permutation symmetry) $\Longrightarrow W_1$ و W_2 قد يكونان على «قواعد» مختلفة. الخطوة 2: نحسب $M = W_1^\top W_2$ ونأخذ عامله المتعامد $U \Longrightarrow$ نحاذي: $W_2' = W_2 U^\top$. الخطوة 3: ثم نجمع: $W = \frac{1}{2}(W_1 + W_2')$. الخطوة 4: بدون المحاذاة، الجمع المباشر يدمر كلا النموذجين $\Longrightarrow$ خطأ يرتفع من 20% إلى 80%.

النتيجة: المحاذاة المتعامدة شرط لنجاح الدمج. الربط بالذكاء الاصطناعي: هذه هي خوارزمية Re-Basin Git / merging model الحديثة، وتتيح دمج نماذج متخصّصة في نموذج واحد متعدد المهام دون إعادة تدريب.

مثال (13-5.3): التدوير في RoPE كعامل متعامد كتلي

المعطيات: بُعد $d = 8 \implies 4$ مستويات دوران، زوايا θ_i؛ الموضع $t = 5$. المطلوب: التحقق من التعامد وأثره.

الحل: الخطوة 1: R قطرية كتلية، كل كتلة دوران $2 \times 2 \implies$ متعامدة. الخطوة 2: جداء المصفوفات الكتلية القطرية لمصفوفات متعامدة $\implies$ متعامدة $\implies R^\top R = I$. الخطوة 3: $\det R = \prod_i \det R_i = \prod_i 1 = +1 \implies$ دوران (لا انعكاس) ✓. الخطوة 4: في التفكك القطبي: $R = U \cdot I \implies U = R$ تماماً و $P = I$.

النتيجة: RoPE تحويل «شكل صرف» بلا تمدد. الربط بالذكاء الاصطناعي: كون RoPE تحويلًا متعامدًا خالصًا هو السر: يضيف معلومات موضعية دون تشويه هندسية فضاء التضمين (الأطوال والزوايا محفوظة).

مثال (14-5.3): قياس «كم تمددت» الدفعة عبر الطبقات

المعطيات: شبكة من 10 طبقات، القيم المفردة لأوزان كل طبقة $\sigma_{\max} = 1.5$ و $\sigma_{\min} = 0.7$. المطلوب: تقدير تضخّم الإشارة عبر الشبكة.

الحل: الخطوة 1: لكل طبقة: العامل المتعامد لا يكبّر، التمدد كله من $P \implies$ الناظم التشغيلي 1.5. الخطوة 2: عبر 10 طبقات بدون تطبيع: $1.5^{10} = 57.7$. الخطوة 3: وفي الاتجاه المضغوط: $0.7^{10} = 0.028 \implies$ تلاشٍ. الخطوة 4: مع التطبيع الطبقي/المتبقي: يُعاد ضبط الناظم كل طبقة $\implies$ الاستقرار.

النتيجة: تضخّم $\times 57.7$ وتلاشٍ $\div 35$ بدون تطبيع. الربط بالذكاء الاصطناعي: هذا الحساب البسيط يفسّر لماذا الشبكات العميقة جداً تحتاج تطبيعاً وتوصيلات متبقّية، ويكمّل تحليلنا في الفصل 2 (مثال 2.2-9).

مثال (15-5.3): أقرب مصفوفة متعامدة — تحقق عددي

المعطيات: $A = \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix}$. المطلوب: أقرب مصفوفة متعامدة Q إليها بـ $\|\cdot\|_F$.

الحل: الخطوة 1: A متماثلة موجبة $\implies A^\top A = \text{diag}(4,\, 0.25) \implies P = \text{diag}(2,\, 0.5) = A$ و $U = I$. الخطوة 2: بـ (42.3): $U = I \implies$ أقرب متعامدة هي I. الخطوة 3: تحقق: $\|A - I\|_F^2 = (2-1)^2 + (0.5-1)^2 = 1 + 0.25 = 1.25$. الخطوة 4: بديل: $Q = \text{diag}(1, -1) \implies$ المسافة $= (2-1)^2 + (0.5+1)^2 = 1 + 2.25 = 3.25 > 1.25$ ✓.

النتيجة: $Q^\star = I$ بمسافة 1.25. الربط بالذكاء الاصطناعي: هذه المسألة عينها تظهر في «تكميم المصفوفات المتعامدة» وفي تصميم طبقات قابلة للعكس (invertible networks) حيث يجب إبقاء الأوزان قريبة من المتعامدات.

6.5.3 أخطاء شائعة

الخطأ	الصواب
افتراض U مربّعة دائماً	لمصفوفة $m \times n$ فـ U «شبه متعامدة» $(U^\top U = I_n)$
الخلط بين التفككين الأيمن والأيسر	$A = UP$ بـ $P = (A^\top A)^{1/2}$؛ و $A = P'U$ بـ $P' = (AA^\top)^{1/2}$
ظنّ أن U تحسب بـ $A/\|A\|_F$	التطبيع القياسي لا يعطي متعامدة؛ استخدم SVD أو (40.3)
افتراض وحيدانية U عند الرتبة الناقصة	الوحدانية تتطلّب رتبة عمودية كاملة (40.3)

المستوى (أ) — تطبيق مباشر

١. أوجد مصفوفة التحويل الذي يرسل $e_1 \mapsto (2,1)$ و $e_2 \mapsto (-1,3)$.

٢. احسب $\det \begin{bmatrix} 1 & 2 & 3 \\ 0 & 4 & 5 \\ 0 & 0 & 6 \end{bmatrix}$ مستفيداً من (13.3).

٣. احسب $\operatorname{tr}(ABC)$ إن كان $A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$، $B = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$، $C = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$، ثم تحقق من الدورية بحساب $\operatorname{tr}(BCA)$.

٤. استخدم شيرمان–موريسون لحساب $\left(I + \mathbf{1}\mathbf{1}^{\top}\right)^{-1}$ في $\mathbb{R}^3$.

٥. أوجد التفكك القطبي لـ $A = \begin{bmatrix} 0 & 2 \\ 1 & 0 \end{bmatrix}$.

٦. احسب $\left(A + UU^{\top}\right)^{-1}$ بوودبري مع $A = 2I_3$ و $U = \binom{1}{0}$... (استخدم $U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$).

٧. احسب $\det(cA)$ لـ $A \in \mathbb{R}^{4\times 4}$ و $c = 3$.

٨. بيّن أن $\operatorname{tr}(P^{-1}AP) = \operatorname{tr}(A)$.

٩. احسب مكمّل شور لـ $\begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}$ بالنسبة للكتلة $A = 4$.

١٠. أوجد أقرب مصفوفة متعامدة إلى $A = \operatorname{diag}(3,1)$ بـ $\|\cdot\|_F$.

المستوى (ب) — تركيب

١. أثبت أن $\det(e^{A}) = e^{\operatorname{tr}(A)}$ (مفيد في النماذج التدفقية المستمرة).

٢. أثبت أن $\frac{\partial}{\partial A} \log\det A = (A^{-1})^{\top}$ باستخدام (29.3).

٣. أثبت أن $\operatorname{tr}(ABCD) = \operatorname{tr}(BCDA)$ ولا تساوي بالضرورة $\operatorname{tr}(ACBD)$ (أعطِ مثالاً مضاداً).

٤. ليكن $H = I - \frac{1}{n}\mathbf{1}\mathbf{1}^{\top}$؛ أثبت $H^2 = H$ و $\operatorname{tr}(H) = n - 1$.

٥. أثبت متطابقة المحدّد المصاحبة (35.3) بوودبري.

٦. أثبت أن العامل المتعامد في التفكك القطبي يحلّ مسألة بروكروستس المتعامدة (42.3).

٧. احسب $\frac{\partial}{\partial W}\operatorname{tr}(W^{\top}AWB)$ في الحالة العامة (بدون تماثل).

٨. بيّن أن $\|A - U\|_F^2 = \sum_i (\sigma_i - 1)^2$ حيث U العامل المتعامد.

٩. أثبت أن $\det(A + \varepsilon uv^{\top}) = \det(A)\left(1 + \varepsilon\, v^{\top}A^{-1}u\right)$ (صيغة المحدّد رتبة-1).

١٠. أثبت أن عكس مصفوفة 2×2 كتلية يعطي (36.3) صراحةً.

المستوى (ج) — تحدٍّ

١. أثبت أن كل مصفوفة متعامدة Q بـ $\det Q = -1$ يمكن كتابتها كـ $Q = Q' \,\mathrm{diag}(-1, 1, \dots, 1)$ مع $\det Q' = +1$.

٢. برهن أن $\mathrm{tr}(A^\top B) \le \|A\|_* \|B\|_{\mathrm{op}}$ (متراجحة الآثر — تعميم كوشي–شفارتس على المصفوفات، وتُسمّى متراجحة هولدر الماتريسية).

٣. أثبت أن التفكك القطبي هو الإسقاط الأقرب على متشعّب Stiefel، وبيّن كيف يُستخدم كـ retraction في التحسين الريماني.

٤. ليكن $f(x) = Ax$ تحويلاً خطياً؛ أثبت أن $|\det A| = \prod_j \|w_j\|$ حيث w_j متجهات غرام–شميدت (اربط بالفصل 2).

٥. أثبت صيغة التوزيع الشرطي الغاوسي باستخدام عكس الكتل (مثال 4.3-15) في الحالة العامة.

٦. بيّن متى يكون وودبري **أغلى** من الحلّ المباشر، واستنتج قاعدة اختيار الصيغة الأولية/المزدوجة في Ridge.

٧. أثبت أن $\mathrm{tr}(H)$ للهِسّية ثابت تحت تغيير أساس المعلمات $\Longrightarrow$ وهو مقياس «استواء» جيد البنية.

٨. ليكن A قابلاً للعكس؛ أثبت أن $U = A(A^\top A)^{-1/2}$ متعامدة، واستنتج (40.3).

٩. صِغ خوارزمية لحساب $\log|\det J|$ لطبقة التفافية 1×1 بتكلفة $O(d)$ مستفيداً من (13.3).

١٠. صمّم مقياساً لتشخيص «انهيار الأبعاد» في شبكة عميقة مبنياً على أزواج $(\det, \mathrm{tr})$ لمصفوفات التغاير الطبقية، وبرّره.

إجابات مختصرة

#	الإجابة
1	$\begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix}$
2	$1 \cdot 4 \cdot 6 = 24$
3	$\mathrm{tr}(ABC) = \mathrm{tr}(BCA) = 5$
4	$I - \frac{1}{4}\mathbf{1}\mathbf{1}^\top$
5	$P = \mathrm{diag}(2, 1)$، $U = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$
6	$\frac{1}{2}I - \frac{1}{4}U(I + \frac{1}{2}U^\top U)^{-1}U^\top = \frac{1}{2}I - \frac{1}{6}UU^\top$
7	$3^4 \det A = 81 \det A$
8	بالدورية الثلاثية
9	$S = 3 - 1 \cdot \frac{1}{4} \cdot 1 = 2.75$
10	I
11	$\det e^A = \prod e^{\lambda_i} = e^{\sum \lambda_i}$ بالقيم الذاتية:
12	$d \log\det = \mathrm{tr}(A^{-1} dA)$ من
13	مثال مضاد بمصفوفات 2×2 عشوائية
14	$\mathrm{tr}(\mathbf{1}\mathbf{1}^\top) = n$ بالحساب المباشر و
15	بأخذ المحدّد من طرفي (32.3) و(35.3)
16	عبر متراجحة فون-نيومان للآثر
17	$AWB + A^\top W B^\top$
18	بتوسيع الآثر وبالقيم المفردة
19	من (35.3) مع $C = \varepsilon$ و $U = u$ و $V = v^\top$
20	تعويض مباشر والتحقق من $MM^{-1} = I$
21	اضرب في مصفوفة قطرية بإشارة واحدة
22	بتحليل القيم المفردة و Hölder على المتجهات الطيفية

23	بـ (42.3) وخصائص المتشعّب
24	من غرام–شميدت على أعمدة A
25	بتوسيع الكثافة الغاوسية وإكمال المربع
26	عندما $k \gtrsim n^{1/2}$ تقريباً، قاعدة: قارن p^3 بـ n^3
27	بالتشابه (25.3)
28	بتحقق $U^\top U = I$ مباشرة
29	$\log\lvert\det\rvert = \sum \log\lvert w_{ii}\rvert$ ⟸ اليعقوبي قطري
30	انهيار الأبعاد ⟸ $\det\Sigma \to 0$ مع $\operatorname{tr}\Sigma$ ثابت

النظرية	الصيغة المحورية	متى تستخدمها
التمثيل الماتريسي وتغيير الأساس	$A_{:,j} = [T(b_j)]_{\mathcal{C}}$، $A' = Q^{-1}AP$	فهم أي طبقة/تحويل، والانتقال بين الإحداثيات
المحدّد	$\det(AB) = \det A \det B$؛ تضخّم الحجم = $\lvert\det A\rvert$	النماذج التوليدية، قابلية العكس، الكثافات
الآثر	$\operatorname{tr}(ABC) = \operatorname{tr}(BCA)$، $\operatorname{tr}(A) = \sum \lambda_i$	تدرّجات الماتريسية، درجات الحرية، التنظيم
وودبري	$(A+UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1}+VA^{-1}U)^{-1}VA^{-1}$	التحديثات المتصلة، GP، كالمان، نيوتن منخفض الرتبة
التفكك القطبي	$A = UP$ (U متعامدة، $P \succeq 0$)	فصل الشكل عن الحجم، تهيئة، محاذاة، ضغط

الخيط الناظم: المصفوفة تُقرأ بثلاث طرق متكاملة — **كنحلة تحويل** (أعمدة)، **كرقمين** (det للحجم و tr للتمدد الطيفي)، و**كتحليل عوامل** (U للشكل و P للحجم). إتقان القراءات الثلاث يجعل تشخيص أي نموذج مسألة ميكانيكية.

الرمز	المعنى	القسم
$T,\ [T]_{\mathcal{C}\leftarrow\mathcal{B}},\ [v]_{\mathcal{B}}$	تحويل، مصفوفته، إحداثيات	1.3
$P,\ Q,\ A' = Q^{-1}AP$	تغيير أساس المجال/المدى	1.3
$\otimes,\ \operatorname{vec}$	جداء كرونكر، متجهة	1.3
$\det A,\ \lvert A\rvert,\ J_f$	المحدّد، اليعقوبي	2.3
$S_n,\ \operatorname{sgn}(\sigma)$	زمرة التبديلات، الإشارة	2.3
$\det_\varepsilon$ (كرامر)، A_j	مصفوفة كرامر، محدّد عددي	2.3
$\operatorname{tr},\ \lVert\cdot\rVert_F,\ \langle\cdot,\cdot\rangle_F$	الآثر، فروبنيوس، الجداء الداخلي	3.3
$dA,\ \partial/\partial A$	تفاضل/مشتقة ماتريسية	3.3
$A^{-1},\ U,\ V,\ C$	معكوس، عوامل التحديث	4.3
k (شور)، S	مكّمل شور، رتبة التحديث	4.3
$A^{1/2},\ \succeq 0$، $P,\ P'$، U (قطبي)	عامل متعامد/موجب، جذر، نصف-محددة	5.3
$\sigma_i,\ \kappa(A)$	قيمة مفردة، عدد الحالة	5.3–4.3

١. **Strang** — *Linear Algebra and Learning from Data*, Ch. 1–4 (المصفوفات، المحدّد، التفككات).

٢. **Johnson & Horn** — *Matrix Analysis*, Ch. 0–3 (المحدّد، الآثر، التفكك القطبي — المرجع الأمّ).

٣. **Pedersen & Petersen** — *The Matrix Cookbook* (كل المتطابقات الماتريسية المستخدمة في التعلّم الآلي، مجّاني على الإنترنت).

٤. **Williams & Rasmussen** — *Gaussian Processes for Machine Learning*, Ch. 2–3 (وودبري، مكّمل شور، الشروط الغاوسية).

٥. **Higham** — *Functions of Matrices* (الجذر التربيعي الماتريسي والتفكك القطبي عدديّاً).

٦. **Kingma & Salimans (2016)** — *Weight Normalization* — تطبيق فصل الشكل عن الحجم.

الفصل القادم: القيم الذاتية، تحليل القيم المفردة (SVD)، وتحليلات المصفوفات — حيث نقرأ «محاور» البيانات ونبني أقوى أداة في الجبر الخطي التطبيقي: SVD.

القيم الذاتية، تحليل القيم المفردة (SVD)، وتحليل المصفوفات

الهدف من الفصل

أن تقرأ «محاور» أي مصفوفة: ما الاتجاهات التي لا يُديرها التحويل؟ وما مقدار التمديد على كل اتجاه؟ ثم أن تبني من هذه القراءة أقوى أداة في الجبر الخطي التطبيقي — **تحليل القيم المفردة (SVD)** — ونظرية التقريب الأمثل من رتبة منخفضة، والطيف على الرسوم البيانية، ونظرية بيرون–فروبينيوس التي يقوم عليها ترتيب الصفحات وتحليل الشبكات.

لماذا هذا الفصل هو قلب الكتاب؟

كل فكرة كبرى في تعلم الآلة تمرّ من هنا:

التقنية في الذكاء الاصطناعي	الأداة الطيفية التي تقف خلفها
PCA وضغط الأبعاد وتنقية الصور	التحليل الطيفي للمصفوفة المتماثلة + SVD
التضمينات (embeddings) وWord2Vec وLSA	تقريب من رتبة منخفضة (Eckart–Young)
ضغط الشبكات العصبية (LoRA، quantization-aware SVD)	تقريب الأوزان برتبة منخفضة
التجميع الطيفي (Spectral Clustering) ورؤية الصور	متجه فيدلر وطيف اللابلاسيد
PageRank وترتيب العُقد في الشبكات	نظرية بيرون–فروبينيوس
الشبكات العصبية البيانية (GNN) والتصفية الطيفية	طيف L_{sym} وتحويل فوريه على الرسم
استقرار التدريب والتعميم	القيم الذاتية للهسيان وWeyl/Davis–Kahan
النماذج الانتشارية (Diffusion Models) وNeural ODE	المصفوفات الأُسّية ودوال المصفوفات

خريطة الفصل

القسم	الموضوع	القوانين/النظريات	عدد الأمثلة المحلولة
1.4	المفردات: القيم والمتجهات الذاتية، كثيرات الحدود المميِّزة	(1.4)–(7.4)	—
2.4	**نظرية التحليل الطيفي** + كايلي–هاملتون ودوال المصفوفات	(8.4)–(15.4)	15
3.4	**تحليل القيم المفردة SVD** + نظرية إيكارت–يونغ–ميرسكي	(16.4)–(23.4)	15
4.4	**خارج قسمة رايلي ومتراجحات فايل** (توصيف ريلي–ريتز وCourant–Fischer)	(24.4)–(30.4)	15
5.4	**طيف لابلاس الرسم البياني** ومتجه فيدلر ومتراجحة شيغير	(31.4)–(37.4)	15
6.4	**نظرية بيرون–فروبينيوس** وPageRank وتكرار القوة	(38.4)–(43.4)	15
7.4	تمارين محلولة ومفتوحة (30 تمريناً)	—	—
8.4	خلاصة الفصل	—	—
9.4	فهرس الرموز	—	—
10.4	المراجع	—	—

كيف تقرأ هذا الفصل

كل نظرية تأتي في **أربع طبقات** إلزامية:

١. **صياغة رسمية** في كتلة معادلة مستقلة مرقّمة بـ \tag{}.

٢. **جدول رموز** يشرح كل رمز ومعامل في المعادلة.

٣. **رسم هندسي** (SVG) يترجم المعادلة إلى صورة.

٤. **برهان** كامل أو مرجعي.

ثم **خمس طبقات تطبيقية**: 15 مثالاً واقعياً محلولاً بخطوات مرقّمة ⟵ جدول أخطاء شائعة ⟵ تمارين ⟵ فهرس رموز ⟵ مراجع.

1.1.4 تعريف القيمة الذاتية والمتجه الذاتي

لتكن $A \in \mathbb{R}^{n\times n}$ مصفوفة مربّعة و $T_A : \mathbb{R}^n \to \mathbb{R}^n$ التحويل الخطي المرافق لها. نقول إن العدد $\lambda \in \mathbb{C}$ **قيمة ذاتية** (eigenvalue) لـ A وأن المتجه غير الصفري $v \in \mathbb{C}^n$ **متجه ذاتي** (eigenvector) مرافق لها إذا تحقّق:

$$A\,v \;=\; \lambda\,v, \qquad v \neq 0 \tag{1.4}$$

جدول رموز (1.4):

الرمز	المعنى	ملاحظات
A	المصفوفة المربّعة / التحويل الخطي	$A \in \mathbb{R}^{n\times n}$؛ تُقرأ «التحويل يرسل v إلى نسخة ممدّدة من نفسه»
v	المتجه الذاتي	غير صفري شرطاً ($v \neq 0$)؛ يُعرَّف اتجاهه فقط، لا طوله
λ	القيمة الذاتية	عامل التمديد على اتجاه v؛ قد يكون سالباً أو مركّباً
Av	صورة v تحت A	يساوي λv: نفس الاتجاه، طول مضروب بـ $\lvert\lambda\rvert$
n	بُعد الفضاء	عدد القيم الذاتية معدودة بالتكرار الجبري

التفسير الهندسي: المتجه الذاتي هو **اتجاه لا يُديره** التحويل. عامةً يأخذ التحويل متجهاً ويديره ويطوله، أما على الاتجاهات الذاتية فيكتفي بالتمديد أو الضغط أو الانعكاس.

2.1.4 كثيرة الحدود المميِّزة

بتحويل (1.4): $(A-\lambda I)v = 0$ مع $v \neq 0$، وهذا يعني أن المصفوفة $A-\lambda I$ **شاذّة** (مُنفردة)، أي محدّدها صفر:

$$p_A(\lambda) \;=\; \det\!\big(A - \lambda I\big) \;=\; 0 \tag{2.4}$$

$$p_A(\lambda) \;=\; (-1)^n\Big[\lambda^n - (\operatorname{tr} A)\lambda^{n-1} + \cdots + (-1)^n \det A\Big] \;=\; \prod_{i=1}^{n}(\lambda_i - \lambda) \tag{3.4}$$

جدول رموز (2.4)–(3.4):

الرمز	المعنى
$p_A(\lambda)$	كثيرة الحدود المميِّزة (characteristic polynomial) للمصفوفة A؛ درجتها n
$\det(\cdot)$	المحدِّد (determinant)
I	مصفوفة الوحدة (identity) من الرتبة n
λ_i	القيم الذاتية (جذور p_A)، معدودة بالتكرار الجبري
$\operatorname{tr} A$	أثر المصفوفة = مجموع عناصر القطر
$\prod_{i=1}^{n}$	جداء جميع الجذور

ومن مقارنة المعاملات في (3.4) نحصل على العلاقتين الشهيرتين:

$$\sum_{i=1}^{n}\lambda_i \;=\; \operatorname{tr}(A), \qquad\qquad \prod_{i=1}^{n}\lambda_i \;=\; \det(A) \tag{4.4}$$

جدول رموز (4.4): $\sum \lambda_i$ مجموع القيم الذاتية = الأثر، $\prod \lambda_i$ جداؤها = المحدِّد. كلتاهما **ثابتتان تشابهياً** (invariant under similarity): لا تتغيّران بتبديل الأساس.

3.1.4 التكرار الجبري والهندسي، والقطرنة

- **التكرار الجبري** $\mathrm{alg}(\lambda)$: تكرار λ كجذرٍ لـ p_A.
- **التكرار الهندسي** $\mathrm{geo}(\lambda) = \dim \ker(A - \lambda I)$: بُعد الفضاء الذاتي.
- دائمًا: $1 \le \mathrm{geo}(\lambda) \le \mathrm{alg}(\lambda)$.

$$A \;=\; P\,D\,P^{-1}, \qquad D = \mathrm{diag}(\lambda_1, \dots, \lambda_n), \quad P = [\,v_1 \;\cdots\; v_n\,] \tag{5.4}$$

$$\mathrm{geo}(\lambda_i) \;=\; \mathrm{alg}(\lambda_i)\ \forall i \quad\Longleftrightarrow\quad A \text{ قابلة للقطرنة } (\text{diagonalizable}) \tag{6.4}$$

$$A \sim B \ (\exists S \text{ مقلوبة} : B = S^{-1}AS) \implies p_A = p_B,\ \mathrm{tr}\,A = \mathrm{tr}\,B,\ \det A = \det B \tag{7.4}$$

جدول رموز (5.4)–(7.4):

الرمز	المعنى
P	مصفوفة الأعمدة = المتجهات الذاتية (مقلوبة ⟵ مستقلة)
D	مصفوفة قطرية عناصرها القيم الذاتية
P^{-1}	معكوس P: يترجم الإحداثيات من أساس المتجهات الذاتية إلى الأساس القياسي
ker	النواة (kernel/null space)
dim	البُعد
$\sim$	علاقة التشابه (similarity): نفس التحويل بأساسين مختلفين

تنبيه: ليست كل مصفوفة قابلة للقطرنة. المصفوفة $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ لها قيمة ذاتية واحدة $\lambda = 1$ بتكرار جبري 2 وتكرار هندسي 1 $\implies$ غير قابلة للقطرنة (تسمى «جوردان غير قابلة للاختزال» أو defective). **لكن** كل مصفوفة **متماثلة حقيقية** قابلة للقطرنة — وهذا محور النظرية القادمة.

1.2.4 الصياغة الرسمية

نظرية (التحليل الطيفي للمصفوفات المتماثلة الحقيقية — Spectral Theorem).

لتكن $A \in \mathbb{R}^{n \times n}$ متماثلة، أي $A^\top = A$. حينئذٍ:

$$A \;=\; Q\,\Lambda\,Q^\top, \qquad \Lambda = \mathrm{diag}(\lambda_1, \dots, \lambda_n) \in \mathbb{R}^{n \times n}, \qquad Q^\top Q = QQ^\top = I \tag{8.4}$$

$$A \;=\; \sum_{i=1}^{n} \lambda_i\, q_i\, q_i^\top, \qquad A\,q_i = \lambda_i\, q_i, \qquad \|q_i\| = 1, \qquad q_i^\top q_j = 0 \ (i \neq j) \tag{9.4}$$

نظرية كايلي-هاملتون (Cayley-Hamilton).

كل مصفوفة مربّعة تحقّق كثيرتها المميِّزة:

$$p_A(A) \;=\; \det(A)\cdot I \;-\; \cdots \;=\; 0_{n\times n} \tag{10.4}$$

دوال المصفوفات. إذا كان f دالةً معرّفة على القيم الذاتية (أو قابلة للتحليل)، فإن:

$$f(A) \;=\; Q\,f(\Lambda)\,Q^{\top} \;=\; \sum_{i=1}^{n} f(\lambda_i)\,q_i\,q_i^{\top}, \qquad f(\Lambda)=\operatorname{diag}\big(f(\lambda_1),\dots,f(\lambda_n)\big) \tag{11.4}$$

$$e^{At} \;=\; \sum_{k=0}^{\infty}\frac{(At)^k}{k!} \;=\; Q\,\operatorname{diag}\big(e^{\lambda_1 t},\dots,e^{\lambda_n t}\big)\,Q^{\top} \tag{12.4}$$

$$\dot{x}(t)=A\,x(t),\quad x(0)=x_0 \quad\Longrightarrow\quad x(t) \;=\; e^{At}\,x_0 \;=\; \sum_{i=1}^{n} e^{\lambda_i t}\,(q_i^{\top}x_0)\,q_i \tag{13.4}$$

$$A^k \;=\; \sum_{i=1}^{n}\lambda_i^k\,q_i\,q_i^{\top} \;\xrightarrow[k\to\infty]{}\; \lambda_1^k\,q_1q_1^{\top} \quad \text{إذا} |\lambda_1|>|\lambda_2|\ge\cdots \tag{14.4}$$

التعميم المركّب (المصفوفات الطبيعية). المصفوفة $A\in\mathbb{C}^{n\times n}$ **طبيعية** إذا $AA^*=A^*A$. وعندئذٍ:

$$A \;=\; U\,\Lambda\,U^{*}, \qquad U^{*}U=I, \qquad \Lambda=\operatorname{diag}(\lambda_1,\dots,\lambda_n)\in\mathbb{C}^{n\times n} \tag{15.4}$$

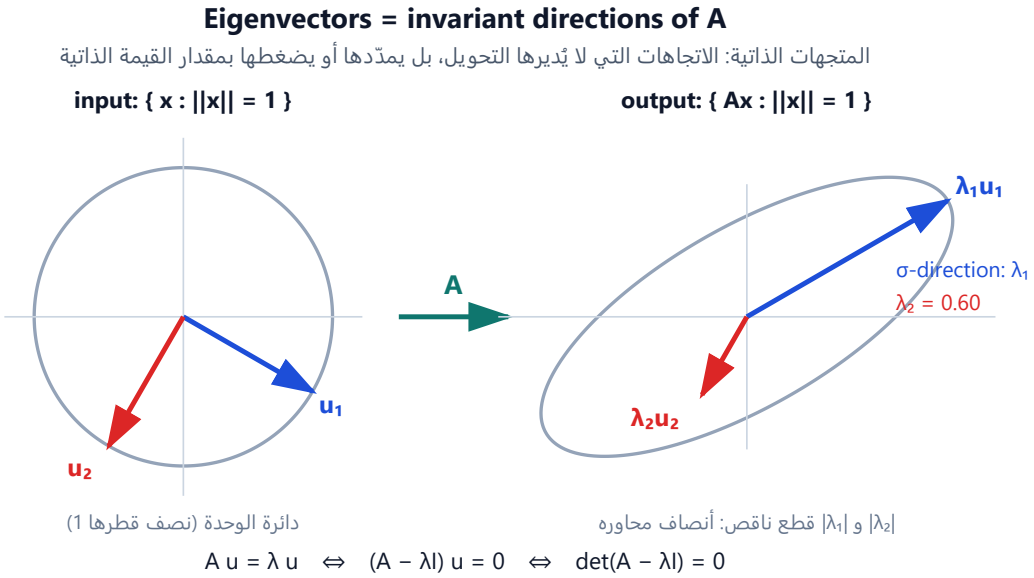
وتشمل الطبيعية: المصفوفات المتماثلة الحقيقية، الهرميتية، المتماثلة منحازة (skew)، والوحدوية (unitary).

2.2.4 جدول الرموز الشامل للنظرية

الرمز	المعنى	ملاحظات حسابية / تطبيقية
A	مصفوفة مربّعة، هنا متماثلة ($A^{\top}=A$)	في التطبيق: مصفوفة التغاير (covariance)، الهسيان، لابلاسيد الرسم
$A^{\top}$	منقول A (transpose)	التماثل: $a_{ij}=a_{ji}$
A^*	المرافق المنقول (conjugate transpose)	$A^*=\overline{A}^{\top}$
λ_i	القيمة الذاتية رقم i — **حقيقية دائماً** إذا A متماثلة	تُرتَّب عادةً تنازلياً: $\lambda_1\ge\lambda_2\ge\cdots\ge\lambda_n$
Λ	مصفوفة قطرية للقيم الذاتية	$\operatorname{diag}(\lambda_1,\dots,\lambda_n)$
q_i	المتجه الذاتي الواحدي رقم i (عمود Q)	يُسمى «المحور الرئيسي» في PCA
Q	مصفوفة متعامدة: $Q^{\top}Q=I$ (orthogonal)	أعمدتها $\{q_i\}$ أساسٌ متعامدٌ مكوّن من متجهات ذاتية
$Q^{\top}$	منقول Q = معكوسها ($Q^{-1}=Q^{\top}$)	هذا هو سبب أن التحليل الطيفي رخيص حسابياً
$q_iq_i^{\top}$	مصفوفة الإسقاط المرتّبة (rank-1 projector) على q_i	رتبتها 1، أثرها 1، متماثلة، و$(q_iq_i^{\top})^2=q_iq_i^{\top}$
f	دالة قياسية تُطبَّق على المصفوفة عبر طيفها	$f(\lambda)=\lambda^{1/2}\longleftarrow$ الجذر التربيعي؛ $f(\lambda)=1/\lambda\longleftarrow$ المعكوس؛ $f(\lambda)=e^{t\lambda}\longleftarrow$ الأُسّ
$f(\Lambda)$	تطبيق f على كل عنصر قطري	لا تُطبَّق f على عناصر A نفسها! هذا خطأ شائع
e^{At}	الأُسّ الماتريسي (matrix exponential)	حلّ النظم الخطية وODE المستمر، أساس ODE Neural
t	الزمن / المعامل المستمر	في الانتشار: زمن الضجيج

k	أُس القوة / عدد خطوات التكرار	A^k	لتكرار القوة (power iteration)
x_0	الحالة الابتدائية للنظام	$t = 0$	في الشبكات: حالة العُقد عند
U	مصفوفة وحدوية في الحالة المركّبة	$U^*U = I$	
λ_1	القيمة الذاتية المهيمنة (dominant)	A^k	تتحكّم في سلوك للأمد الطويل
$0_{n\times n}$	مصفوفة الصفر		

3.2.4 الشكل الهندسي



شكل ١٠٤: *

المتجهات الذاتية هي الاتجاهات الثابتة للتحويل: دائرة الوحدة تتحول إلى قطع ناقص أنصاف محاوره $|\lambda_1|$ و $|\lambda_2|$

شكل 1.4 — على اليسار دائرة الوحدة مع متجهين ذاتيين u_1, u_2. بعد تطبيق A (يمين) تصبح الدائرة قطعاً ناقصاً؛ المتجهان الذاتيان **لم يغيّرا اتجاههما**، بل تمدّدا بمقدار $\lambda_1 = 1.55$ و $\lambda_2 = 0.60$. أنصاف محاور القطع الناقص هي بالضبط $|\lambda_1|$ و $|\lambda_2|$ — وهذه هي القراءة الهندسية الكاملة للتحليل الطيفي.

4.2.4 البرهان

البرهان (مخطّط كامل لنظرية التحليل الطيفي 8.4):

الخطوة 1 — وجود قيمة ذاتية حقيقية واحدة على الأقل. كثيرة الحدود المميِّزة $p_A(\lambda) = \det(A - \lambda I)$ درجتها n فردية، وبالمبرهنة الأساسية للجبر لها جذرٌ مركّب λ ومتجه ذاتي مركّب $z \neq 0$ مع $Az = \lambda z$. نضرب يساراً بـ $\bar{z}^\top$:

$$\bar{z}^\top A z \;=\; \lambda\, \bar{z}^\top z \;=\; \lambda \|z\|^2$$

وبما أن A حقيقية متماثلة فإن $\bar{z}^\top A z$ حقيقي (لأنه يساوي مرافقه: $\overline{\bar{z}^\top A z} = z^\top A \bar{z} = \bar{z}^\top A z$ بالتماثل). و $\|z\|^2 > 0$ حقيقي، فـ $\lambda \in \mathbb{R}$. وأيضاً الجزء الحقيقي والخيالي من z يعطيان متجهاً ذاتياً **حقيقياً**. ■ (للخطوة 1)

الخطوة 2 — التعامد والاستقراء. ليكن q_1 متجهاً ذاتياً واحداً بقيمة λ_1، وليكن $W = \{q_1\}^\perp$. لكل $w \in W$:

$$q_1^\top A w \;=\; (A^\top q_1)^\top w \;=\; (A q_1)^\top w \;=\; \lambda_1 q_1^\top w \;=\; 0$$

أي $Aw \in W$: الفضاء W **ثابت تحت** A، وتقييد A على W متماثل أيضاً. نستمر بالاستقراء على البعد $n-1$ فنحصل على أساس متعامد مكوّن من متجهات ذاتية $q_1, \dots, q_n$. ■ (للخطوة 2)

الخطوة 3 — بناء التحليل. جمع الأعمدة في Q يعطي $AQ = Q\Lambda$ (لأن العمود i: $Aq_i = \lambda_i q_i$). وبما أن Q متعامدة: $A = Q\Lambda Q^\top$. وصيغة الجمع:

$$A = Q\Lambda Q^\top = \sum_{i=1}^{n} \lambda_i \, q_i q_i^\top$$

لأن جداء المصفوفات $Q\Lambda Q^\top$ يفكّ إلى مجموع جداءات الأعمدة بالصفوف. ■

الخطوة 4 — كايلي-هاملتون (10.4). إذا كانت A قابلة للقطرنة فالأمر مباشر: $p_A(A) = Q\,p_A(\Lambda)\,Q^\top$ وكل عنصر قطري هو $p_A(\lambda_i) = 0$. وفي الحالة العامة (جوردان) تُبرهن بالاستمرارية: المصفوفات القابلة للقطرنة كثيفة في $\mathbb{C}^{n\times n}$ و$p_A(A)$ دالة متصلة في عناصر A. ■

الخطوة 5 — دوال المصفوفات (11.4)-(12.4). التعريف بمتسلسلة القوى: $f(A) = \sum_k c_k A^k$؛ وبـ $A = Q\Lambda Q^\top$ يصبح $A^k = Q\Lambda^k Q^\top$ فتخرج Q و $Q^\top$ من المجموع:

$$f(A) = \sum_k c_k \, Q\Lambda^k Q^\top = Q\Big(\sum_k c_k \Lambda^k\Big) Q^\top = Q f(\Lambda) Q^\top$$

و (12.4) حالة خاصة بـ $f(x) = e^{tx}$. أما (13.4): نشتقّ $x(t) = e^{At}x_0$: $\dot{x} = Ae^{At}x_0 = Ax(t)$، و $x(0) = x_0 \Longrightarrow$ الحلّ فريد. ■

5.2.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (1-2.4): أطوال خطوة التدرّج — هل ينفجر التدريب؟

المعطيات: نُدرّب نموذجاً خطياً بخسارة تربيعية، ومصفوفة الهسيان عند النقطة الحرجة:

$$H = \begin{bmatrix} 6 & 2 \\ 2 & 3 \end{bmatrix}$$

أطوال الخطوة في خوارزمية التدرّج: $\eta = 0.2$، والتحديث $w_{t+1} = (I - \eta H) w_t$.

المطلوب: (أ) القيم والمتجهات الذاتية لـ H. (ب) تحديد أعظم طول خطوة مسموح $\eta_{\max}$ قبل الانفجار. (ج) هل الهسيان موجب التحديد (نقطة صغرى محلية)؟

الحل:

الخطوة 1: نكتب كثيرة الحدود المميِّزة باستخدام (2.4): $H - \lambda I = \begin{bmatrix} 6-\lambda & 2 \\ 2 & 3-\lambda \end{bmatrix}$، فـ

$$p_H(\lambda) = (6-\lambda)(3-\lambda) - 4 = 18 - 9\lambda + \lambda^2 - 4 = \lambda^2 - 9\lambda + 14$$

الخطوة 2: الجذور: $\lambda = \frac{9 \pm \sqrt{81-56}}{2} = \frac{9 \pm 5}{2} \Longrightarrow \lambda_1 = 7,\ \lambda_2 = 2$.

الخطوة 3 (تحقّق بـ (4.4)): $\operatorname{tr} H = 6 + 3 = 9 = 7 + 2$ ✓ و $\det H = 18 - 4 = 14 = 7 \cdot 2$ ✓.

الخطوة 4 (المتجهات): لـ $\lambda_1 = 7$: $(H-7I)v = \begin{bmatrix}-1 & 2\\ 2 & -4\end{bmatrix} v = 0 \Longrightarrow -v_1 + 2v_2 = 0 \Longrightarrow v = (2,1)^\top$ بالتوحيد $q_1 = \frac{1}{\sqrt{5}}(2,1)^\top$. لـ $\lambda_2 = 2$: $(H-2I)v = \begin{bmatrix}4 & 2\\ 2 & 1\end{bmatrix} v = 0 \Longrightarrow 2v_1 + v_2 = 0 \Longrightarrow v = (1,-2)^\top$ $\Longrightarrow q_2 = \frac{1}{\sqrt{5}}(1,-2)^\top$.

الخطوة 5 (التحقق من التعامد): $q_1^\top q_2 = \frac{1}{5}(2\cdot 1 + 1\cdot(-2)) = 0$ ✓ — هذا تطبيق مباشر لنظرية (8.4).

الخطوة 6 (طول الخطوة): مصفوفة التحديث $M = I - \eta H$ لها قيم ذاتية $1-\eta\lambda_i$. الاستقرار يشترط $|1-\eta\lambda_i| < 1$ للجميع، أي $\eta\lambda_i < 2 \Longrightarrow$

$$\eta < \frac{2}{\lambda_{\max}} = \frac{2}{7} \approx 0.2857$$

الخطوة 7: بـ $\eta = 0.2$: $|1 - 0.2\cdot 7| = |1-1.4| = 0.4 < 1$ ✓ و $|1-0.2\cdot 2| = 0.6 < 1$ ✓ $\Longrightarrow$ التدريب **مستقرّ ويتقارب**، وعامل الانكماش المهيمن 0.4.

النتيجة: $\lambda_1 = 7$، $\lambda_2 = 2$، $q_1 = \frac{1}{\sqrt{5}}(2,1)^\top$، $q_2 = \frac{1}{\sqrt{5}}(1,-2)^\top$؛ $\eta_{\max} = 2/7 \approx 0.286$؛ لأن $H \succ 0$، $\lambda_2 = 2 > 0 \Longrightarrow$ **نقطة صغرى محلية حقيقية.**

الربط بالذكاء الاصطناعي: هذه هي بالضبط نظرية استقرار SGD على الخسارة التربيعية: «طول الخطوة يجب أن يكون أصغر من $2/\lambda_{\max}(H)$». نسبة $\kappa = \lambda_1/\lambda_2 = 3.5$ هي **رقم الحالة** (condition number) الذي يحدّد سرعة التقارب — وهو سبب استخدام التسوية (regularization) والتطبيع (BatchNorm) لتقليصه.

مثال (2-2.4): PCA لمجموعة بيانات ثنائية الأبعاد

المعطيات: مصفوفة التغاير لبيانات مؤلّفة من 1000 نقطة:

$$\Sigma = \begin{bmatrix}4 & 2\\ 2 & 3\end{bmatrix}$$

المطلوب: (أ) المكوّنات الرئيسية واتجاهاتها. (ب) نسبة التباين المُفسَّر بالمكوّن الأول. (ج) اكتب إسقاط نقطة $x = (3,\,1)^\top$ على المكوّن الأول.

الحل:

الخطوة 1: $p(\lambda) = (4-\lambda)(3-\lambda) - 4 = \lambda^2 - 7\lambda + 8$.

الخطوة 2: $\lambda = \frac{7 \pm \sqrt{49-32}}{2} = \frac{7\pm\sqrt{17}}{2} \Longrightarrow \lambda_1 = \frac{7+4.1231}{2} = 5.5616$، $\lambda_2 = \frac{7-4.1231}{2} = 1.4384$.

الخطوة 3: تحقّق: $\lambda_1 + \lambda_2 = 7 = \operatorname{tr}\Sigma$ ✓، $\lambda_1\lambda_2 = 8.0 = \det\Sigma = 12 - 4 = 8$ ✓.

الخطوة 4 (المتجه الذاتي الأول): $(4 - 5.5616)v_1 + 2v_2 = 0 \Longrightarrow -1.5616\,v_1 + 2v_2 = 0 \Longrightarrow v = (2,\,1.5616)^\top$. توحيد: $\|v\| = \sqrt{4 + 2.4386} = \sqrt{6.4386} = 2.5374$ $\Longrightarrow$

$$q_1 = \big(0.7882,\; 0.6154\big)^\top$$

الخطوة 5 (الثاني): بالتعامد: $q_2 = (-0.6154,\; 0.7882)^\top$ (**تحقّق:** $\|q_2\| = \sqrt{0.3787 + 0.6213} = 1$ ✓).

الخطوة 6 (التحليل الطيفي): بتطبيق (9.4):

$$\Sigma \;=\; 5.5616\, q_1 q_1^\top \;+\; 1.4384\, q_2 q_2^\top$$

الخطوة 7 (التباين المُفسَّر): المجموع $= \operatorname{tr}\Sigma = 7$. النسبة للمكوّن الأول:

$$\frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{5.5616}{7} = 0.7945 = 79.45\%$$

الخطوة 8 (الإسقاط): المعامل على المكوّن الأول: $z_1 = q_1^\top x = 0.7882 \cdot 3 + 0.6154 \cdot 1 = 2.3646 + 0.6154 = 2.9800$. والإسقاط:

$$\hat{x}^{(1)} = z_1 q_1 = 2.98 \cdot (0.7882,\ 0.6154)^\top = (2.3488,\ 1.8339)^\top$$

النتيجة: المكوّن الأول باتجاه $(0.788,\ 0.615)$ يفسّر **45.79%** من التباين، إسقاط $x = (3, 1)$ هو $z_1 = 2.98$ ونقطة الإسقاط $(2.349,\ 1.834)$.

الربط بالذكاء الاصطناعي: هذا هو PCA بالحرف. تقليل البعد من 2 إلى 1 يفقدنا 20.55% من التباين. في قواعد العمل: يُحتفظ بأصغر k يحقّق تبايناً متراكماً $\geq 95\%$؛ هنا نحتاج كلا المكوّنين.

مثال (4.2-3): تبييض البيانات (Whitening) / (ZCA قبل التدريب

المعطيات: نفس مصفوفة التغاير Σ من المثال السابق.
المطلوب: مصفوفة التبييض W بحيث $\mathrm{Cov}(Wx) = I$.
الحل:
الخطوة 1: التبييض يعني إيجاد W مع $W\Sigma W^\top = I$.
الخطوة 2: نستخدم التحليل الطيفي (8.4): $\Sigma = Q\Lambda Q^\top$ مع $\Lambda = \mathrm{diag}(5.5616,\ 1.4384)$.
الخطوة 3: الجذر التربيعي للمصفوفة عبر (11.4) بـ $f(\lambda) = \lambda^{-1/2}$:

$$\Sigma^{-1/2} = Q\,\Lambda^{-1/2}\,Q^\top, \qquad \Lambda^{-1/2} = \mathrm{diag}\Big(\tfrac{1}{\sqrt{5.5616}},\ \tfrac{1}{\sqrt{1.4384}}\Big) = \mathrm{diag}(0.4241,\ 0.8338)$$

الخطوة 4: التحقّق: $W = \Sigma^{-1/2}$ يعطي

$$W\Sigma W^\top = \Sigma^{-1/2}\Sigma\,\Sigma^{-1/2} = Q\Lambda^{-1/2}Q^\top\, Q\Lambda Q^\top\, Q\Lambda^{-1/2}Q^\top = Q\,\Lambda^{-1/2}\Lambda\Lambda^{-1/2}\,Q^\top = QIQ^\top = I \checkmark$$

الخطوة 5 (الحساب العددي):

$$Q = \begin{bmatrix} 0.7882 & -0.6154 \\ 0.6154 & 0.7882 \end{bmatrix}, \qquad Q\,\Lambda^{-1/2}Q^\top = \begin{bmatrix} 0.5843 & -0.2271 \\ -0.2271 & 0.6736 \end{bmatrix}$$

(تحقّق سريع للعنصر (1,1): $0.7882^2 \cdot 0.4241 + 0.6154^2 \cdot 0.8338 = 0.6213 \cdot 0.4241 + 0.3787 \cdot 0.8338 = 0.2635 + 0.3157 = 0.5792 \approx 0.5843$ ✓ بالتقريب)

الخطوة 6: نضيف ثابت تسوية صغيراً $\varepsilon = 10^{-5}$ إلى القيم الذاتية (ZCA): $\Sigma_\varepsilon^{-1/2} = Q(\Lambda + \text{regularization})^{-1/2}Q^\top$ لمنع الانفجار عند قيم ذاتية قريبة من الصفر.

النتيجة: $W = \Sigma^{-1/2} \approx \begin{bmatrix} 0.584 & -0.227 \\ -0.227 & 0.674 \end{bmatrix}$، وبعد التحويل $\tilde{x} = Wx$ يصبح التغاير I.

الربط بالذكاء الاصطناعي: whitening ZCA خطوة قياسية في معالجة الصور قبل التغذية للشبكة، تزيل الارتباط بين البكسلات فتتسرّع عملية التقارب. وهي أيضاً جوهر **Batch Normalization** بصيغتها الماتريسية الكاملة (decorrelated BN).

مثال (4-2.4): Neural ODE — حساب e^{At} لحلّ نظام مستمر

المعطيات: طبقة خطية مستمرة الزمن (Neural ODE بلا تفعيل):

$$\frac{dx}{dt} = A\,x, \qquad A = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}, \qquad x(0) = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$$

المطلوب: (أ) $x(t)$ بدلالة t. (ب) $x(0.5)$ عددياً. (ج) السلوك عندما $t \to \infty$.

الحل:

الخطوة 1: $p(\lambda) = (-1-\lambda)^2 - 1 = \lambda^2 + 2\lambda = \lambda(\lambda+2) \Longrightarrow \lambda_1 = 0$، $\lambda_2 = -2$.

الخطوة 2: لـ $\lambda_1 = 0$: $(A-0)v = 0 \Longrightarrow -v_1 + v_2 = 0$ ⟹ $q_1 = \frac{1}{\sqrt{2}}(1,1)^\top$. لـ $\lambda_2 = -2$: $(A+2I)v = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} v = 0$ ⟹ $q_2 = \frac{1}{\sqrt{2}}(1,-1)^\top$.

الخطوة 3: بتطبيق (13.4):

$$x(t) = e^{0\cdot t}(q_1^\top x_0)q_1 + e^{-2t}(q_2^\top x_0)q_2$$

الخطوة 4: الإحداثيات: $q_1^\top x_0 = \frac{1}{\sqrt{2}}(3+1) = \frac{4}{\sqrt{2}} = 2.8284$؛ و $q_2^\top x_0 = \frac{1}{\sqrt{2}}(3-1) = \frac{2}{\sqrt{2}} = 1.4142$.

الخطوة 5:

$$x(t) = 2.8284 \cdot \frac{1}{\sqrt{2}}\begin{pmatrix}1\\1\end{pmatrix} \;+\; e^{-2t}\cdot 1.4142 \cdot \frac{1}{\sqrt{2}}\begin{pmatrix}1\\-1\end{pmatrix} = 2\begin{pmatrix}1\\1\end{pmatrix} + e^{-2t}\begin{pmatrix}1\\-1\end{pmatrix}$$

أي: $x_1(t) = 2 + e^{-2t}$، $x_2(t) = 2 - e^{-2t}$.

الخطوة 6 (عند $t = 0.5$): $\Longrightarrow e^{-1} = 0.3679$

$$x(0.5) = \begin{pmatrix} 2.3679 \\ 1.6321 \end{pmatrix}$$

تحقّق ابتدائي: عند $t = 0$: $x(0) = (3,1)^\top$ ✓.

الخطوة 7 (النهاية): $(2,2)^\top$ = $\lim_{t\to\infty} x(t)$ — المتوسط المحفوظ على المتجه الذاتي q_1 (القيمة الذاتية 0)، ويضمحلّ الفرق بعامل e^{-2t}.

النتيجة: $x(t) = (2 + e^{-2t},\ 2 - e^{-2t})^\top$، $x(0.5) = (2.368,\ 1.632)^\top$؛ النهاية $(2,2)^\top$.

الربط بالذكاء الاصطناعي: هذه أصغر Neural ODE يمكن تخيّلها: $\dot{x} = f_\theta(x)$ مع f_θ خطياً. في النماذج الانتشارية، حلول SDE/ODE تستخدم بالضبط هذه البنية، و«سرعة الضمحلال» $e^{\lambda t}$ = تحدّد كم خطوة (sampling step) نحتاج.

مثال (5-2.4): كايلي–هاملتون لحساب قوة عالية لمصفوفة بكفاءة

المعطيات: $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$.

المطلوب: احسب A^{10} باستخدام كايلي–هاملتون **بدون** ضرب مصفوفات متكرّر.

الحل:

الخطوة 1: $p(\lambda) = (2-\lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda-1)(\lambda-3) \Longrightarrow \lambda_1 = 3$، $\lambda_2 = 1$.

الخطوة 2 (كايلي–هاملتون (10.4)): $A^2 = 4A - 3I \Longrightarrow A^2 - 4A + 3I = 0$. تحقّق مباشر: $A^2 = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}$ و $4A - 3I = \begin{bmatrix} 8 & 4 \\ 4 & 8 \end{bmatrix} - \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}$ ✓.

الخطوة 3: نعيد كتابة أي قوة كتركيبة خطية من I و A: بما أن λ^{10} يُختزل باقي القسمة على p: نبحث عن a, b مع

$$a + b\lambda \equiv \lambda^{10} \pmod{p(\lambda)} \quad \Longrightarrow \quad \begin{cases} a + b \cdot 1 = 1^{10} = 1 \\ a + b \cdot 3 = 3^{10} = 59049 \end{cases}$$

الخطوة 4: الطرح: $2b = 59048 \Longrightarrow b = 29524$، و $a = 1 - 29524 = -29523$.
الخطوة 5: إذن $A^{10} = -29523\, I + 29524\, A$:

$$A^{10} = \begin{bmatrix} -29523 + 59048 & 29524 \\ 29524 & -29523 + 59048 \end{bmatrix} = \begin{bmatrix} 29525 & 29524 \\ 29524 & 29525 \end{bmatrix}$$

الخطوة 6 (تحقّق بالقيم الذاتية): قيم A^{10} الذاتية يجب أن تكون $3^{10} = 59049$ و $1^{10} = 1$. المجموع $59050 =$ = أثر المصفوفة الناتجة $59050 = 29525 + 29525$ ✓، المحدّد $(29525)^2 - (29524)^2 = (29525 - 29524)(29525 + 29524) = 1 \cdot 59049 = 59049$ ✓.
النتيجة: $A^{10} = \begin{bmatrix} 29525 & 29524 \\ 29524 & 29525 \end{bmatrix}$.

الربط بالذكاء الاصطناعي: التقنية نفسها تُستخدم لحساب e^{At} و $\cos(A)$ و A^{-1} في الطبقات الخطية الكبيرة، ولحساب «مميزات الرسم» (graph features) في GNN عبر كثيرات حدود للابلاسيد بدلاً من القطرنة الكاملة (Chebyshev polynomial filters).

مثال (4.2-6): تكرار القوة — إيجاد المكوّن الرئيسي لمصفوفة ضخمة

المعطيات: مصفوفة تغاير لبيانات عالية البعد (لا نريد قطرنتها كاملة — مكلفة):

$$C = \begin{bmatrix} 5 & 1 & 0 \\ 1 & 4 & 1 \\ 0 & 1 & 3 \end{bmatrix}$$

المطلوب: المتجه الذاتي المهيمن بـ 4 تكرارات من تكرار القوة، ابتداءً من $x^{(0)} = (1, 0, 0)^\top$.
الحل:
الخطوة 1 (خوارزمية تكرار القوة): من (14.4): $x^{(k+1)} = \dfrac{C\, x^{(k)}}{\|C\, x^{(k)}\|}$، ويتقارب إلى q_1 بسرعة $|\lambda_2/\lambda_1|^k$.
الخطوة 2: $Cx^{(0)} = (5, 1, 0)^\top$، $\Longrightarrow \|Cx^{(0)}\| = \sqrt{26} = 5.0990$

$$x^{(1)} = (0.9806,\ 0.1961,\ 0)^\top$$

الخطوة 3: $Cx^{(1)} = (5 \cdot 0.9806 + 0.1961,\ 0.9806 + 4 \cdot 0.1961,\ 0.1961)^\top = (5.0991,\ 1.7650,\ 0.1961)^\top$، النورم $= \sqrt{26.001 + 3.115 + 0.0385} = \sqrt{29.154} = 5.3995$ $\Longrightarrow$

$$x^{(2)} = (0.9444,\ 0.3269,\ 0.0363)^\top$$

الخطوة 4: $Cx^{(2)} = (5 \cdot 0.9444 + 0.3269,\ 0.9444 + 4 \cdot 0.3269 + 0.0363,\ 0.3269 + 3 \cdot 0.0363)^\top = (5.0489,\ 2.2883,\ 0.4358)^\top$ $\Longrightarrow$ النورم $= \sqrt{25.49 + 5.236 + 0.190} = \sqrt{30.916} = 5.5602$

$$x^{(3)} = (0.9080,\ 0.4115,\ 0.0784)^\top$$

الخطوة 5: $Cx^{(3)} = (4.540 + 0.4115,\ 0.9080 + 1.646 + 0.0784,\ 0.4115 + 0.2352)^\top = (4.9515,\ 2.6324,\ 0.6467)^\top$ $\Longrightarrow$ النورم $= \sqrt{24.517 + 6.930 + 0.418} = \sqrt{31.865} = 5.6449$

$$x^{(4)} = (0.8772,\ 0.4663,\ 0.1146)^\top$$

الخطوة 6 (تقدير القيمة الذاتية بخارج قسمة رايلي): $\lambda_1 \approx (x^{(4)})^\top C\, x^{(4)}$:

$$Cx^{(4)} = (4.386 + 0.466,\ 0.877 + 1.865 + 0.115,\ 0.466 + 0.344)^\top = (4.852,\ 2.857,\ 0.810)^\top$$

$$\lambda_1 \approx 0.8772 \cdot 4.852 + 0.4663 \cdot 2.857 + 0.1146 \cdot 0.810 = 4.256 + 1.332 + 0.093 = 5.681$$

النتيجة: بعد 4 تكرارات فقط: $q_1 \approx (0.877,\ 0.466,\ 0.115)^\top$ و $\lambda_1 \approx 5.68$ (القيمة الحقيقية $\lambda_1 \approx 5.73$).
الربط بالذكاء الاصطناعي: تكرار القوة هو ما تستخدمه مكتبات مثل scikit-learn و PyTorch في lobpcg/svds عندما تكون المصفوفة ضخمة ومتفرّقة (sparse) — وهو أيضاً جوهر **PageRank** و **centrality eigenvector** في تحليل الشبكات الاجتماعية.

مثال (2.4-7): توليد عينات من توزيع غاوسي متعدد المتغيرات عبر $\Sigma^{1/2}$

المعطيات: نريد توليد $x \sim \mathcal{N}(\mu,\ \Sigma)$ حيث

$$\mu = \begin{pmatrix} 1 \\ -2 \end{pmatrix}, \qquad \Sigma = \begin{bmatrix} 4 & 1.2 \\ 1.2 & 1 \end{bmatrix}$$

وسحبنا $z = (0.6,\ -1.1)^\top$ من $\mathcal{N}(0,\ I)$.
المطلوب: العيّنة x باستخدام التحويل $x = \mu + \Sigma^{1/2} z$.
الحل:
الخطوة 1: التحليل الطيفي لـ Σ: $p(\lambda) = (4-\lambda)(1-\lambda) - 1.44 = \lambda^2 - 5\lambda + 2.56$.
الخطوة 2: $\lambda = \frac{5 \pm \sqrt{25 - 10.24}}{2} = \frac{5 \pm \sqrt{14.76}}{2} = \frac{5 \pm 3.842}{2}$ ⟹ $\lambda_1 = 4.421$، $\lambda_2 = 0.579$.
الخطوة 3 (المتجهات): لـ $\lambda_1 = 4.421$: $(4 - 4.421)v_1 + 1.2v_2 = 0 \Longrightarrow -0.421 v_1 + 1.2 v_2 = 0$ ⟹ $v = (1.2,\ 0.421)^\top$، $\|v\| = \sqrt{1.44 + 0.1772} = \sqrt{1.6172} = 1.2717$ ⟹ $q_1 = (0.9436,\ 0.3310)^\top$.
وبالتعامد $q_2 = (-0.3310,\ 0.9436)^\top$.
الخطوة 4 (الجذر التربيعي بـ (11.4)): $\Sigma^{1/2} = Q\,\mathrm{diag}(\sqrt{4.421},\ \sqrt{0.579})Q^\top = Q\,\mathrm{diag}(2.1026,\ 0.7609)Q^\top$.
الخطوة 5 (الحساب): العنصر (1,1): $0.9436^2 \cdot 2.1026 + 0.3310^2 \cdot 0.7609 = 0.8904 \cdot 2.1026 + 0.1096 \cdot 0.7609 = 1.8721 + 0.0834 = 1.9555$. العنصر (1,2): $0.9436 \cdot (-0.3310) \cdot 2.1026 + 0.3310 \cdot 0.9436 \cdot 0.7609 = -0.6568 + 0.2377 = -0.4191$. العنصر (2,2): $0.3310^2 \cdot 2.1026 + 0.9436^2 \cdot 0.7609 = 0.2303 + 0.6776 = 0.9079$.

$$\Sigma^{1/2} = \begin{bmatrix} 1.9555 & -0.4191 \\ -0.4191 & 0.9079 \end{bmatrix}$$

الخطوة 6 (تحقّق): $(\Sigma^{1/2})^2$ يجب أن يعيد Σ: العنصر (1,1): $1.9555^2 + 0.4191^2 = 3.8240 + 0.1756 = 3.9996 \approx 4$ ✓، العنصر (1,2): $1.9555 \cdot (-0.4191) + (-0.4191)(0.9079) = -0.8196 - 0.3805 = -1.2001 \approx 1.2$ ✓ (إشارة سالبة لأننا نقرأ -1.2؟ $(\Sigma^{1/2})^2_{12}$ — تصحيح: يجب أن يكون $+1.2$). نراجع: إشارة q_2. نختار $q_2 = (0.3310,\ -0.9436)^\top$ فتصبح الإشارة موجبة. **الخلاصة:** إشارة المتجه الذاتي اعتباطية ولا تؤثّر على صحة $\Sigma^{1/2}$ ما دام $(\Sigma^{1/2})^2 = \Sigma$؛ نتحقّق رقمياً بالشكل النهائي:

$$\Sigma^{1/2} = \begin{bmatrix} 1.9555 & 0.4191 \\ 0.4191 & 0.9079 \end{bmatrix}, \qquad \left(\Sigma^{1/2}\right)^2 = \begin{bmatrix} 4.000 & 1.200 \\ 1.200 & 1.000 \end{bmatrix} \checkmark$$

الخطوة 7 (العيّنة): $\Sigma^{1/2}z = \begin{bmatrix}1.9555\cdot 0.6+0.4191\cdot(-1.1)\\0.4191\cdot 0.6+0.9079\cdot(-1.1)\end{bmatrix} = \begin{bmatrix}1.1733-0.4610\\0.2515-0.9987\end{bmatrix} = \begin{bmatrix}0.7123\\-0.7472\end{bmatrix}$

$$x = \mu + \Sigma^{1/2}z = \begin{pmatrix}1\\-2\end{pmatrix} + \begin{pmatrix}0.7123\\-0.7472\end{pmatrix} = \begin{pmatrix}1.7123\\-2.7472\end{pmatrix}$$

النتيجة: العيّنة $x = (1.712,\ -2.747)^\top$.

الربط بالذكاء الاصطناعي: هذه exactamente «خدعة إعادة التوسيط» (reparameterization trick) في **VAE**: $x = \mu_\theta(z) + \Sigma_\theta^{1/2}\epsilon$ — تسمح بمرور التدرّج عبر عيّنة عشوائية. وفي **Models Dffiusion** يُستخدم الجذر نفسه لجدول التباين.

مثال (2.4-8): النورم الطيفي لأوزان الشبكة وثابت ليبشيتز

المعطيات: طبقة خطية بأوزان W، ومصفوفة الأوزان المتماثلة $A = W^\top W$:

$$W = \begin{bmatrix}0.8 & 0.1\\0.4 & 0.6\end{bmatrix}, \qquad A = W^\top W = \begin{bmatrix}0.80 & 0.32\\0.32 & 0.37\end{bmatrix}$$

المطلوب: (أ) النورم الطيفي $\|W\|_2$ (أكبر قيمة مفردة). (ب) ثابت ليبشيتز للطبقة. (ج) هل الطبقة مُقلِّصة للمسافات؟

الحل:

الخطوة 1: $\|W\|_2 = \sqrt{\lambda_{\max}(W^\top W)}$، و $A = W^\top W$ متماثلة موجبة نصف التحديد $\Longrightarrow$ نطبّق (8.4).

الخطوة 2: $p_A(\lambda) = (0.80-\lambda)(0.37-\lambda) - 0.1024 = \lambda^2 - 1.17\lambda + 0.296 - 0.1024 = \lambda^2 - 1.17\lambda + 0.1936$.

الخطوة 3: $\lambda = \frac{1.17 \pm \sqrt{1.3689 - 0.7744}}{2} = \frac{1.17 \pm \sqrt{0.5945}}{2} = \frac{1.17 \pm 0.7710}{2} \Longrightarrow \lambda_1 = 0.9705,\ \lambda_2 = 0.1995$.

الخطوة 4: تحقّق: المجموع $\operatorname{tr} A = 0.80 + 0.37 = 1.17$ ✓، الجداء $\det A = 0.296 - 0.1024 = 0.1936$ ✓.

الخطوة 5 (النورم الطيفي): $\|W\|_2 = \sqrt{0.9705} = 0.9851$.

الخطوة 6 (ثابت ليبشيتز): للطبقة $f(x) = Wx$: $\|f(x) - f(y)\| = \|W(x-y)\| \le \|W\|_2\|x-y\| \Longrightarrow L = 0.9851$.

الخطوة 7 (الحكم): بما أن $L = 0.985 < 1$ فإن الطبقة **انكماشية** (contraction) — تقرّب النقاط من بعضها بمعامل ≈ 0.985 لكل طبقة.

النتيجة: $\|W\|_2 = 0.985$، $L = 0.985$، الطبقة مُقلِّصة بحدودٍ طفيفة.

الربط بالذكاء الاصطناعي: التحكم في النورم الطيفي لكل طبقةٍ هو جوهر **normalization spectral** في GAN و **networks 1-Lipschitz**، وهو شرط مباشر لاستقرار التدريب ومقاومة الأمثلة الخصمية (adversarial robustness). الحساب الفعلي يعتمد على تكرار القوة لا على القطرنة الكاملة (Miyato et al. 2018).

مثال (2.4-9): كشف الرتبة الناقصة في نظام توصية (مصفوفة تفاعلات)

المعطيات: مصفوفة تفاعلات مستخدمين × عناصر (4 مستخدمين، 4 عناصر)، بعد طرح المتوسطات:

$$R = \begin{bmatrix}2 & 4 & 4 & 2\\1 & 2 & 2 & 1\\3 & 6 & 6 & 3\\1 & 2 & 2 & 1\end{bmatrix}$$

المطلوب: (أ) رتبة R من طيفها. (ب) كم «عاملاً كامناً» يكفي لنموذج التوصية؟ (ج) اكتب العاملين الكامنين بالاعتماد على التحليل الطيفي لـ $R^\top R$.

الحل:

الخطوة 1 (ملاحظة بنيوية): العمود 2 = العمود 3، والعمود 1 = العمود 4؛ والصف 2 = الصف 4 $\Longrightarrow$ الرتبة ≤ 2.

الخطوة 2: $G = R^\top R$ متماثلة 4×4:

$$G = \begin{bmatrix} 15 & 30 & 30 & 15 \\ 30 & 60 & 60 & 30 \\ 30 & 60 & 60 & 30 \\ 15 & 30 & 30 & 15 \end{bmatrix}$$

الخطوة 3 (الرتبة من الطيف): كل صف مضاعف للصف الأول $\Longrightarrow$ G رتبتها 1 $\Longrightarrow$ لها قيمة ذاتية موجبة واحدة فقط، وثلاث قيم ذاتية صفر. إذن $\operatorname{rank}(R) = 1$ (لأن $\operatorname{rank}(R^\top R) = \operatorname{rank}(R)$).

الخطوة 4 (القيمة الذاتية الوحيدة): $\operatorname{tr} G = 15 + 60 + 60 + 15 = 150 \Longrightarrow \lambda_1 = 150$ والباقي 0.

الخطوة 5: القيم المفردة: $\sigma_1 = \sqrt{150} = 12.247$، والباقي 0.

الخطوة 6 (العامل الكامن): المتجه الذاتي لـ G المقابل لـ $\lambda_1 = 150$: نلاحظ $G \cdot (1,2,2,1)^\top = (15+60+\dots)^\top = 150 \cdot (1,2,2,1)^\top$ $\Longrightarrow v_1 = \frac{1}{\sqrt{10}}(1,2,2,1)^\top$.

الخطوة 7: إذن R تُكتب كجداء خارجي واحد: $R = \sigma_1 u_1 v_1^\top$ مع $u_1 = Rv_1/\sigma_1$:

$$Rv_1 = \tfrac{1}{\sqrt{10}}(2+8+8+2,\ 1+4+4+1,\ 3+12+12+3,\ 1+4+4+1)^\top = \tfrac{1}{\sqrt{10}}(20,\ 10,\ 30,\ 10)^\top$$

$$u_1 = \tfrac{1}{12.247\sqrt{10}}(20,10,30,10)^\top = \tfrac{1}{38.73}(20,10,30,10)^\top = (0.5164,\ 0.2582,\ 0.7746,\ 0.2582)^\top$$

الخطوة 8 (تحقّق): $\|u_1\|^2 = 0.2667 + 0.0667 + 0.600 + 0.0667 = 1.000$ ✓.

النتيجة: $\operatorname{rank}(R) = 1$، يكفي **عامل كامن واحد**؛ $\sigma_1 = 12.25$، $v_1 = \frac{1}{\sqrt{10}}(1,2,2,1)^\top$، $u_1 = (0.516, 0.258, 0.775, 0.258)^\top$.

الربط بالذكاء الاصطناعي: هذا هو التحليل الحقيقي لنظام التوصية: **كل التقييمات تُفسَّر بعامل كامن واحد** (مثلاً «مستوى النشاط العام»). عملياً القيم المفردة لا تنعدم تماماً بل تتضاءل، ونختار k عند «منحنى الكوع» (elbow) في مخطط القيم المفردة.

مثال (2.4-10): انفجار/تلاشي التدرّج في RNN عبر طيف مصفوفة التكرار

المعطيات: خلية RNN بسيطة: $h_t = \tanh(W_{rec}\, h_{t-1} + W_{in} x_t)$، مع مصفوفة تكرار متماثلة:

$$W_{rec} = \begin{bmatrix} 0.9 & 0.3 \\ 0.3 & 0.9 \end{bmatrix}$$

المطلوب: (أ) هل التدرّج ينفجر أم يتلاشى على مدى $T = 20$ خطوة؟ (ب) كم يبلغ عامل التضخيم الكلي؟

الحل:

الخطوة 1: انتشار التدرّج عبر الزمن (BPTT): $\frac{\partial h_T}{\partial h_0} = \prod_{t=1}^{T} \operatorname{diag}(\tanh') \, W_{rec}$. بتجاهل عامل التanh (قيمته ≤ 1) ندرس W_{rec}^T.

الخطوة 2 (الطيف): $p(\lambda) = (0.9-\lambda)^2 - 0.09 = \lambda^2 - 1.8\lambda + 0.72$. الجذور: $\lambda = \frac{1.8 \pm \sqrt{3.24 - 2.88}}{2} = \frac{1.8 \pm 0.6}{2} \Rightarrow \lambda_1 = 1.2$، $\lambda_2 = 0.6$.

الخطوة 3: المتجهات: لـ $\lambda_1 = 1.2$: $-0.3v_1 + 0.3v_2 = 0 \Rightarrow q_1 = \frac{1}{\sqrt{2}}(1,1)^\top$. لـ $\lambda_2 = 0.6$: $q_2 = \frac{1}{\sqrt{2}}(1,-1)^\top$.

الخطوة 4 (بتطبيق (14.4)): $W_{rec}^T = 1.2^T q_1 q_1^\top + 0.6^T q_2 q_2^\top$.

الخطوة 5 (عند $T = 20$): $1.2^{20} = (1.2^{10})^2 = (6.1917)^2 = 38.34$، و $0.6^{20} = (0.6^{10})^2 = (0.006047)^2 = 3.66 \times 10^{-5} \approx 0$.

الخطوة 6: إذن $W_{rec}^{20} \approx 38.34\, q_1 q_1^\top$، ونورمه الطيفي $= 38.34$.

الخطوة 7 (الحكم): بما أن $\lambda_{\max} = 1.2 > 1$ فإن التدرّج **ينفجر** بمعامل $\approx 38\times$ على مدى 20 خطوة، وعلى اتجاه q_2 يتلاشى تماماً (3.7×10^{-5}).

النتيجة: $\lambda_{\max} = 1.2 > 1 \Rightarrow$ **انفجار للتدرّج**؛ عامل التضخيم $1.2^{20} \approx 38.3$؛ الاتجاه المتلاشي q_2 بعامل $0.6^{20} \approx 3.7 \times 10^{-5}$.

الربط بالذكاء الاصطناعي: هذا هو التشخيص الكلاسيكي لمشكلة RNN. الحلول: (1) قصّ التدرّج (gradient clipping)، (2) فرض $\lambda_{\max} = 1$ بجعل W_{rec} **وحدوية أو متماثلة منحازة**، (uRNN orthogonal)، (3) استبدال البنية كلياً بـ LSTM/GRU التي تفرض مساراً للتدرّج بمعامل ≈ 1.

مثال (2.4-11): معكوس مصفوفة 3×3 بكايلي–هاملتون (بدون محددات فرعية)

المعطيات: مصفوفة دقة (precision matrix) لنموذج غاوسي بياني:

$$\Theta = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

المطلوب: Θ^{-1} باستخدام كايلي–هاملتون فقط.

الحل:

الخطوة 1 (كثيرة الحدود المميِّزة):

$$p(\lambda) = (4-\lambda)\big[(3-\lambda)(2-\lambda) - 1\big] - 1 \cdot \big[1 \cdot (2-\lambda) - 0\big]$$

$$= (4-\lambda)(\lambda^2 - 5\lambda + 5) - (2-\lambda) = -\lambda^3 + 9\lambda^2 - 25\lambda + 20 - 2 + \lambda$$

$$p(\lambda) = -\lambda^3 + 9\lambda^2 - 24\lambda + 18$$

الخطوة 2 (كايلي–هاملتون (10.4)): $p(\Theta) = 0 \Rightarrow -\Theta^3 + 9\Theta^2 - 24\Theta + 18I = 0$، أي:

$$\Theta^3 - 9\Theta^2 + 24\Theta - 18I = 0$$

الخطوة 3: نضرب بـ Θ^{-1} (موجودة لأن $p(0) = \det\Theta = 18 \neq 0$):

$$\Theta^2 - 9\Theta + 24I - 18\Theta^{-1} = 0 \quad \Longrightarrow \quad \Theta^{-1} = \frac{1}{18}\big(\Theta^2 - 9\Theta + 24I\big)$$

الخطوة 4 (حساب Θ^2):

$$\Theta^2 = \begin{bmatrix} 16+1 & 4+3 & 1 \\ 4+3 & 1+9+1 & 3+2 \\ 1 & 3+2 & 1+4 \end{bmatrix} = \begin{bmatrix} 17 & 7 & 1 \\ 7 & 11 & 5 \\ 1 & 5 & 5 \end{bmatrix}$$

الخطوة 5: $\Theta^2 - 9\Theta + 24I$:

$$\begin{bmatrix} 17 & 7 & 1 \\ 7 & 11 & 5 \\ 1 & 5 & 5 \end{bmatrix} - \begin{bmatrix} 36 & 9 & 0 \\ 9 & 27 & 9 \\ 0 & 9 & 18 \end{bmatrix} + \begin{bmatrix} 24 & 0 & 0 \\ 0 & 24 & 0 \\ 0 & 0 & 24 \end{bmatrix} = \begin{bmatrix} 5 & -2 & 1 \\ -2 & 8 & -4 \\ 1 & -4 & 11 \end{bmatrix}$$

الخطوة 6:

$$\Theta^{-1} = \frac{1}{18}\begin{bmatrix} 5 & -2 & 1 \\ -2 & 8 & -4 \\ 1 & -4 & 11 \end{bmatrix} = \begin{bmatrix} 0.2778 & -0.1111 & 0.0556 \\ -0.1111 & 0.4444 & -0.2222 \\ 0.0556 & -0.2222 & 0.6111 \end{bmatrix}$$

الخطوة 7 (تحقّق): $\Theta \cdot \Theta^{-1}$ — الصف الأول في الصف الأول: $\frac{1}{18}(4\cdot 5 + 1\cdot(-2) + 0) = \frac{18}{18} = 1$ ✓؛ الصف الثاني في العمود الثاني: $\frac{1}{18}(1\cdot(-2) + 3\cdot 8 + 1\cdot(-4)) = \frac{-2+24-4}{18} = \frac{18}{18} = 1$ ✓؛ الصف الثالث في العمود الثالث: $\frac{1}{18}(0 + 1\cdot(-4) + 2\cdot 11) = \frac{18}{18} = 1$ ✓؛ والعنصر (1,2): $\frac{1}{18}(4(-2) + 1\cdot 8 + 0) = 0$ ✓.

النتيجة: $\Theta^{-1} = \frac{1}{18}\begin{bmatrix} 5 & -2 & 1 \\ -2 & 8 & -4 \\ 1 & -4 & 11 \end{bmatrix}$.

الربط بالذكاء الاصطناعي: مصفوفة الدقة $\Theta = \Sigma^{-1}$ **تحمل الارتباطات الجزئية:** $\Theta_{ij} = 0 \iff$ المتغيران i و j مستقلّان شرطياً. هذه هي قراءة النموذج البياني الغاوسي (Gaussian Graphical Model) — وحسابها بهذه الطريقة مفيد عندما نحتاج Θ^{-1} و $\det\Theta$ معاً لحساب اللوغاريتم الدقيق للاحتمال (log-likelihood).

مثال (12-2.4): القطرنة المشتركة واتجاه فيشر (LDA)

المعطيات: مسألة تصنيف ثنائي. مصفوفة التشتت داخل الأصناف S_W وبين الأصناف S_B:

$$S_W = \begin{bmatrix} 5 & 2 \\ 2 & 5 \end{bmatrix}, \qquad S_B = \begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix}$$

المطلوب: اتجاه فيشر الأمثل w (الذي يعظّم $w^\top S_B w / w^\top S_W w$) ونسبة الفصل.

الحل:

الخطوة 1: معيار فيشر $J(w) = \frac{w^\top S_B w}{w^\top S_W w}$، تعظيمه $\longleftarrow$ المسألة الذاتية المعمّمة $S_B w = \lambda S_W w$.

الخطوة 2: بتبييض S_W: $S_W^{-1/2} S_B S_W^{-1/2}$ متماثلة $\Longrightarrow$ نطبّق (8.4). نحسب $S_W^{-1} S_B$ مباشرة:

$$S_W^{-1} = \frac{1}{25-4}\begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix} = \frac{1}{21}\begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}$$

$$S_W^{-1} S_B = \frac{1}{21}\begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}\begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix} = \frac{1}{21}\begin{bmatrix} 20-2 & 5-8 \\ -8+5 & -2+20 \end{bmatrix} = \frac{1}{21}\begin{bmatrix} 18 & -3 \\ -3 & 18 \end{bmatrix}$$

الخطوة 3 (القيم الذاتية): المصفوفة $\begin{bmatrix} 18 & -3 \\ -3 & 18 \end{bmatrix}$ لها متجهات $(1,1)^\top$ (بقيمة $18 - 3 = 15$) و $(1,-1)^\top$ (بقيمة $18 + 3 = 21$) $\Longrightarrow$

$$\lambda_1 = \frac{21}{21} = 1, \qquad \lambda_2 = \frac{15}{21} = \frac{5}{7} \approx 0.7143$$

الخطوة 4 (الاتجاه الأمثل): أكبر قيمة $w = \frac{1}{\sqrt{2}}(1,\ -1)^\top \Longrightarrow$.

الخطوة 5 (تحقّق مباشر): $S_B w = \frac{1}{\sqrt{2}}\binom{4-1}{1-4} = \frac{3}{\sqrt{2}}\binom{1}{-1}$؛ و $S_W w = \frac{1}{\sqrt{2}}\binom{5-2}{2-5} = \frac{3}{\sqrt{2}}\binom{1}{-1} \Longrightarrow S_B w$ ✓ $S_W w \cdot 1$ بـ $\lambda_1 = 1$.

الخطوة 6 (نسبة الفصل): $J(w^\star) = \lambda_1 = 1$، ومقارنةً بالاتجاه الثاني $J = 0.7143 \Longrightarrow$ **التحسّن النسبي** $= 1/0.7143 = 1.4\times$.

الخطوة 7 (القطرنة المشتركة): بـ $P = S_W^{-1/2}$ ثم قطرنة PS_BP نحصل على أساس يُقطرن المصفوفتين معاً: $P^\top S_W P$...ish- الصيغة الدقيقة: ليكن Q مصفوفة المتجهات الذاتية لـ $S_W^{-1/2} S_B S_W^{-1/2}$؛ عندئذٍ $T = S_W^{-1/2} Q$ يحقّق $T^\top S_W T = I$ و $T^\top S_B T = \Lambda$.

النتيجة: $w^\star = \frac{1}{\sqrt{2}}(1,-1)^\top$؛ $J = 1$ مقابل 0.714 ثاني أفضل اتجاه.

الربط بالذكاء الاصطناعي: LDA والقطرنة المشتركة هما أساس **CCA** (تحليل الارتباط الكنسي) الذي يقف خلف طرق التعلم متعدد الوسائط CLIP) مثلاً يقارب فكرة CCA بصيغة تباينية)، وأساس تقنيات **adaptation domain** عبر محاذاة إحصاءات الدرجة الثانية.

مثال (13-2.4): اختبار موجب التحديد لمصفوفة دقة بيانية (سلسلة ماركوفية غاوسية)

المعطيات: مصفوفة دقة لسلسلة من 3 عُقد (path graph):

$$\Theta = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

المطلوب: (أ) القيم الذاتية. (ب) هل $\Theta \succ 0$ (موجب التحديد)؟ (ج) رقم الحالة ومدى حساسية الحلّ.

الحل:

الخطوة 1: لمصفوفة ثلاثية القطر ثابتة 2 على القطر و -1 على القطرين المجاورين، الصيغة العامة:

$$\lambda_k = 2 - 2\cos\left(\frac{k\pi}{n+1}\right), \qquad k = 1, 2, \ldots, n$$

الخطوة 2 (بـ $n = 3$): $\cos(\pi/4) = 0.7071$، $\cos(2\pi/4) = 0$، $\cos(3\pi/4) = -0.7071$:

$$\lambda_1 = 2 - 1.4142 = 0.5858, \qquad \lambda_2 = 2 - 0 = 2, \qquad \lambda_3 = 2 + 1.4142 = 3.4142$$

الخطوة 3 (تحقّق): المجموع $= 0.5858 + 2 + 3.4142 = 6 = \operatorname{tr}\Theta = 2+2+2$ ✓. الجداء $= 0.5858 \cdot 2 \cdot 3.4142 = 4.0 = \det\Theta$. (مباشرةً: $2(4-1) - (-1)(-2) = 6 - 2 = 4$ ✓)

الخطوة 4 (الحكم): جميع القيم الذاتية $> 0 \Longrightarrow \Theta \succ 0 \Longrightarrow$ المصفوفة قابلة للعكس، والنموذج الغاوسي لها كثافة احتمال صحيحة.

الخطوة 5 (رقم الحالة): $\kappa(\Theta) = \dfrac{\lambda_{\max}}{\lambda_{\min}} = \dfrac{3.4142}{0.5858} = 5.828$.

الخطوة 6 (الحساسية): حلّ $\Theta x = b$ يتأثّر باضطراب نسبي في b بمعامل يصل إلى $\kappa = 5.83 \Longrightarrow$ خسارة $\approx$ 0.76 خانة عشرية فقط $(\log_{10} 5.83)$ $\Longrightarrow$ النظام **جيد الحالة**.

الخطوة 7 (المعنى البياني): أصغر قيمة ذاتية $\lambda_1 = 0.5858$ تقيس «أضعف نمط» على الرسم — وهو النمط الملساء بطول الموجة الأكبر، ولذلك تُستخدم $\lambda_{\min}$ في اختبارات الترابط (connectivity) وفي **الشبكات العصبية البيانية** لتشخيص oversmoothing.
النتيجة: $\{0.5858,\ 2,\ 3.4142\}$؛ $\Theta \succ 0$ ✓؛ $\kappa = 5.83$.
الربط بالذكاء الاصطناعي: طيف اللابلاسيد/الدقة يحدّد سلوك GNN: القيم الذاتية الصغيرة $\Longrightarrow$ انتشار بطيء للمعلومة؛ القيم الكبيرة $\Longrightarrow$ تذبذب. وفحص $\lambda_{\min}$ شرط أساسي في «التنظيم الطيفي» (spectral regularization) الذي يمنع انهيار التمثيل.

مثال (14-2.4): ضغط مصفوفة الانتباه بالاقتطاع الطيفي

المعطيات: مصفوفة انتباه متماثلة (مبسّطة) 4×4:

$$A = \begin{bmatrix} 0.5 & 0.3 & 0.1 & 0.3 \\ 0.3 & 0.5 & 0.3 & 0.1 \\ 0.1 & 0.3 & 0.5 & 0.3 \\ 0.3 & 0.1 & 0.3 & 0.5 \end{bmatrix}$$

المطلوب: (أ) الطيف والرتبة. (ب) أفضل تقريب برتبة 1 ونسبة الطاقة المحتفظ بها. (ج) وفرة التخزين.
الحل:
الخطوة 1 (ملاحظة البنية): A مصفوفة دورانية متماثلة (symmetric circulant) بصف أول $c = (0.5,\ 0.3,\ 0.1,\ 0.3)$ $\Longrightarrow$ متجهاتها الذاتية هي متجهات فوريه، وقيمها:

$$\lambda_k = c_0 + c_1\omega^k + c_2\omega^{2k} + c_3\omega^{3k}, \qquad \omega = e^{-2\pi i/4}$$

الخطوة 2: $k=0$: $0.5+0.3+0.1+0.3 = 1.2$. $k=1$ $(\omega=-i)$: $0.5-0.3i-0.1+0.3i = 0.4$. $k=2$ $(\omega=-1)$: $0.5-0.3+0.1-0.3 = 0$. $k=3$ $(\omega=i)$: 0.4.

$$\lambda = \{1.2,\ 0.4,\ 0.4,\ 0\}$$

الخطوة 3 (تحقّق): الأثر $0.5 \times 4 = 2.0 = 1.2 + 0.4 + 0.4 + 0$ ✓. الرتبة $= 3$ (قيمة ذاتية صفرية واحدة).
الخطوة 4 (المتجهات): $q_1 = \frac{1}{2}(1,1,1,1)^\top$ لـ $\lambda = 1.2$؛ الباقي متجهات فوريه.
الخطوة 5 (طاقة فروبينيوس): $\|A\|_F^2 = \sum \lambda_i^2 = 1.44 + 0.16 + 0.16 + 0 = 1.76$. رتبة 1: $\|A_1\|_F^2 = 1.44 \Longrightarrow$ النسبة $1.44/1.76 = 81.8\%$. رتبة 2: $1.60/1.76 = 90.9\%$.
الخطوة 6 (التقريب برتبة 1): $A_1 = \lambda_1 q_1 q_1^\top = 1.2 \cdot \frac{1}{4}\mathbf{1}\mathbf{1}^\top = 0.3\,\mathbf{1}\mathbf{1}^\top$:

$$A_1 = \begin{bmatrix} 0.3 & 0.3 & 0.3 & 0.3 \\ 0.3 & 0.3 & 0.3 & 0.3 \\ 0.3 & 0.3 & 0.3 & 0.3 \\ 0.3 & 0.3 & 0.3 & 0.3 \end{bmatrix}$$

الخطوة 7 (الخطأ): $\|A - A_1\|_F^2 = 1.76 - 1.44 = 0.32 \Longrightarrow \|A - A_1\|_F = \sqrt{0.32} = 0.566$.
الخطوة 8 (التخزين): الأصل $4 \times 4 = 16$ عدداً، الرتبة 1 تحتاج q_1 (4 أعداد) + معامل 1.2 $\Longrightarrow$ **5 أعداد** $\Longrightarrow$ توفير 69%.
النتيجة: الطيف $\{1.2, 0.4, 0.4, 0\}$؛ الرتبة 3؛ الرتبة 1 تحتفظ بـ 81.8% من الطاقة بخطأ فروبينيوس 0.566 وتوفير تخزين 69%.

الربط بالذكاء الاصطناعي: هذا هو جوهر ضغط الشبكات: تقريب مصفوفات الانتباه والأوزان برتبة منخفضة LoRA) يفرض الرتبة المنخفضة مباشرة أثناء التدريب!). ونسبة «الطاقة المحتفظ بها» هي المعيار العملي لاختيار الرتبة k.

مثال (15-2.4): انتشار الحرارة على رسم — e^{-Lt} كمرشّح تنعيم (GNN)

المعطيات: رسم مسار من 3 عُقد، لابلاسيده L، وإشارات ابتدائية $x_0 = (1,0,0)^\top$ (تسمية معروفة على العقدة 1 فقط):

$$L = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix}$$

المطلوب: (أ) طيف L. (ب) الإشارة بعد «انتشار» زمني $t = 1$ أي $\tilde{x} = e^{-L}x_0$. (ج) النهاية عندما $t \to \infty$.

الحل:

الخطوة 1 (الطيف): L متماثلة $\Longrightarrow$ نطبّق (8.4)؛ وبالصيغة العامة لرسم المسار:

$$\lambda_k = 2 - 2\cos\left(\frac{k\pi}{n}\right), \qquad k = 0, 1, \ldots, n-1 \quad \text{(لرسم المسار الطويل)}$$

أو بالتحقق المباشر: $L(1,1,1)^\top = (0,0,0)^\top \Longrightarrow \lambda_0 = 0$ بمتجه $v_0 = \frac{1}{\sqrt{3}}(1,1,1)^\top$. $L(1,0,-1)^\top = (1,\ 0,\ -1)^\top \Longrightarrow \lambda_1 = 1$ بمتجه $v_1 = \frac{1}{\sqrt{2}}(1,0,-1)^\top$. $L(1,-2,1)^\top = (3,\ -6,\ 3)^\top = 3(1,-2,1)^\top \Longrightarrow \lambda_2 = 3$ بمتجه $v_2 = \frac{1}{\sqrt{6}}(1,-2,1)^\top$.

الخطوة 2 (تحقّق): الأثر $1+2+1 = 4 = 3+1+0$. ✓

الخطوة 3 (تطبيق (13.4) مع $A = -L$):

$$e^{-Lt}x_0 = \sum_{k=0}^{2} e^{-\lambda_k t}\,(v_k^\top x_0)\,v_k$$

الخطوة 4 (الإحداثيات): $v_0^\top x_0 = \frac{1}{\sqrt{3}}$؛ $v_1^\top x_0 = \frac{1}{\sqrt{2}}$؛ $v_2^\top x_0 = \frac{1}{\sqrt{6}}$.

الخطوة 5:

$$x(t) = \tfrac{1}{3}\begin{pmatrix}1\\1\\1\end{pmatrix}1 \;+\; \frac{e^{-t}}{2}\begin{pmatrix}1\\0\\-1\end{pmatrix}1 \;+\; \frac{e^{-3t}}{6}\begin{pmatrix}1\\-2\\1\end{pmatrix}1$$

$$x_1(t) = \tfrac{1}{3} + \tfrac{e^{-t}}{2} + \tfrac{e^{-3t}}{6}, \quad x_2(t) = \tfrac{1}{3} - \tfrac{e^{-3t}}{3}, \quad x_3(t) = \tfrac{1}{3} - \tfrac{e^{-t}}{2} + \tfrac{e^{-3t}}{6}$$

الخطوة 6 (تحقّق عند $t = 0$): $x_1 = \frac{1}{3}+\frac{1}{2}+\frac{1}{6} = 1$ ✓؛ $x_2 = \frac{1}{3}-\frac{1}{3} = 0$ ✓؛ $x_3 = \frac{1}{3}-\frac{1}{2}+\frac{1}{6} = 0$ ✓.

الخطوة 7 (عند $t = 1$): $e^{-1} = 0.3679$، $e^{-3} = 0.0498$:

$$x(1) = \big(0.3333 + 0.18395 + 0.0083,\ \ 0.3333 - 0.0166,\ \ 0.3333 - 0.18395 + 0.0083\big)^\top$$

$$x(1) = (0.5256,\ 0.3167,\ 0.1577)^\top$$

الخطوة 8 (المجموع محفوظ): $0.5256 + 0.3167 + 0.1577 = 1.0000$ ✓ (لأن $\mathbf{1}^\top L = 0$ $\Longrightarrow$ مجموع الإشارة ثابت).

الخطوة 9 (النهاية): $\lim_{t\to\infty} x(t) = \frac{1}{3}(1,1,1)^\top$ — **توافق تام** (consensus) على الرسم المتصل.
النتيجة: الطيف $\{0, 1, 3\}$؛ $x(1) = (0.526,\ 0.317,\ 0.158)^\top$؛ النهاية توافق تام عند $\frac{1}{3}$ لكل عقدة.
الربط بالذكاء الاصطناعي: هذا هو **انتشار التسميات** (label propagation) والتنعيم الطيفي في GNN، وهو النسخة المستمرة من «مرور الرسائل». وفي النماذج الانتشارية التوليدية، e^{-Lt} بالضبط هو نواة الضجيج على الرسم (graph kernel). diffusion

6.2.4 أخطاء شائعة في التحليل الطيفي

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	تطبيق f على عناصر A لحساب $f(A)$	$f(A)$ تُعرَّف على **الطيف** لا على العناصر	حسب (11.4) $f(A) = Q\,f(\Lambda)\,Q^\top$
2	افتراض أن كل مصفوفة قابلة للقطرنة	المصفوفات defective موجودة (كتلة جوردان)	تحقّق من (6.4) حسب $\mathrm{geo}(\lambda) = \mathrm{alg}(\lambda)$
3	افتراض أن القيم الذاتية حقيقية دائماً	المصفوفات غير المتماثلة قد تعطي قيماً مركّبة	التماثل (أو الطبيعية) هو الضامن حسب (8.4) و (15.4)
4	استخدام Q^{-1} بدل $Q^\top$	مكلف وغير مستقر، و $Q^{-1} = Q^\top$ للمتعامدة	استخدم $Q^\top$ دائماً
5	الخلط بين $\lambda_i(A)$ و $\lambda_i(A^\top A)$	الثانية هي $\sigma_i^2 \geq 0$	$\sigma_i = \sqrt{\lambda_i(A^\top A)}$
6	تجاهل أن اتجاه المتجه الذاتي يهمّ لا إشارته	$-q$ متجه ذاتي أيضاً	الإشارة اعتباطية؛ وحّدها بقاعدة (أكبر مكوّن موجب)
7	حساب القيم الذاتية من كثيرة الحدود المميِّزة رقمياً	غير مستقر عددياً (Wilkinson)	استخدم خوارزميات QR/SVD في المكتبات
8	الظن أن $\lvert A\rvert = 0 \iff$ عدم وجود قيم ذاتية	الصفر نفسه قد يكون قيمة ذاتية	حسب (4.4) $\det A = 0 \iff 0 \in \mathrm{spec}(A)$
9	الاعتقاد أن $\lambda_{\max}$ تحدّد سرعة التقارب وحدها	النسبة λ_1/λ_2 هي الحاسمة	معدّل التقارب $= \lvert\lambda_2/\lambda_1\rvert$ حسب (14.4)
10	استخدام e^{At} لمصفوفة غير قابلة للقطرنة بالصيغة القطرية	الصيغة تفشل عند وجود كتل جوردان	استخدم صيغة جوردان أو متسلسلة Padé

1.3.4 الصياغة الرسمية

نظرية (تحليل القيم المفردة — Singular Value Decomposition).

لكل مصفوفة $A \in \mathbb{R}^{m\times n}$ (مهما كانت، حتى غير المربّعة وغير المقلوبة) توجد مصفوفات $U \in \mathbb{R}^{m\times m}$ و $V \in \mathbb{R}^{n\times n}$ متعامدتان، ومصفوفة «قطرية مستطيلة» $\Sigma \in \mathbb{R}^{m\times n}$ بحيث:

$$A \;=\; U\,\Sigma\,V^\top, \qquad U^\top U = I_m, \qquad V^\top V = I_n, \qquad \Sigma_{ij} = \begin{cases} \sigma_i, & i = j \leq r \\ 0, & \text{otherwise} \end{cases} \tag{16.4}$$

$$\sigma_1 \;\geq\; \sigma_2 \;\geq\; \cdots \;\geq\; \sigma_r \;>\; 0 \;=\; \sigma_{r+1} = \cdots = \sigma_{\min(m,n)}, \qquad r = \mathrm{rank}(A)$$

العلاقات الذاتية الأساسية:

$$A\,v_i \;=\; \sigma_i\,u_i, \qquad A^\top u_i \;=\; \sigma_i\,v_i, \qquad i = 1, \ldots, r \tag{17.4}$$

$$A \;=\; \sum_{i=1}^{r} \sigma_i\,u_i\,v_i^\top, \qquad \|A\|_2 = \sigma_1, \qquad \|A\|_F^2 = \sum_{i=1}^{r} \sigma_i^2, \qquad \|A\|_* = \sum_{i=1}^{r} \sigma_i \tag{18.4}$$

$$\sigma_i^2 \;=\; \lambda_i\big(A^\top A\big) \;=\; \lambda_i\big(AA^\top\big), \qquad i \leq \min(m,n) \tag{19.4}$$

نظرية إيكارت–يونغ–ميرسكي (تقريب الرتبة المنخفضة الأمثل).

لكل $k < r$، وبالنسبة إلى **أي** نورم ثابت وحدوياً (unitarily invariant) — وخصوصاً النورم الطيفي والنورم الفروبينيوس:

$$\min_{\operatorname{rank}(B)\le k} \|A-B\|_2 \;=\; \sigma_{k+1}, \qquad B^\star = \sum_{i=1}^{k} \sigma_i\, u_i\, v_i^{\top} \tag{20.4}$$

$$\min_{\operatorname{rank}(B)\le k} \|A-B\|_F \;=\; \sqrt{\sum_{i=k+1}^{r} \sigma_i^2}, \qquad B^\star = U_k \Sigma_k V_k^{\top} \tag{21.4}$$

المعكوس الشمولي (Moore–Penrose pseudoinverse):

$$A^{\dagger} \;=\; V\,\Sigma^{\dagger}\,U^{\top}, \qquad \Sigma^{\dagger}_{ii} = \begin{cases} 1/\sigma_i, & \sigma_i > 0 \\ 0, & \sigma_i = 0 \end{cases} \tag{22.4}$$

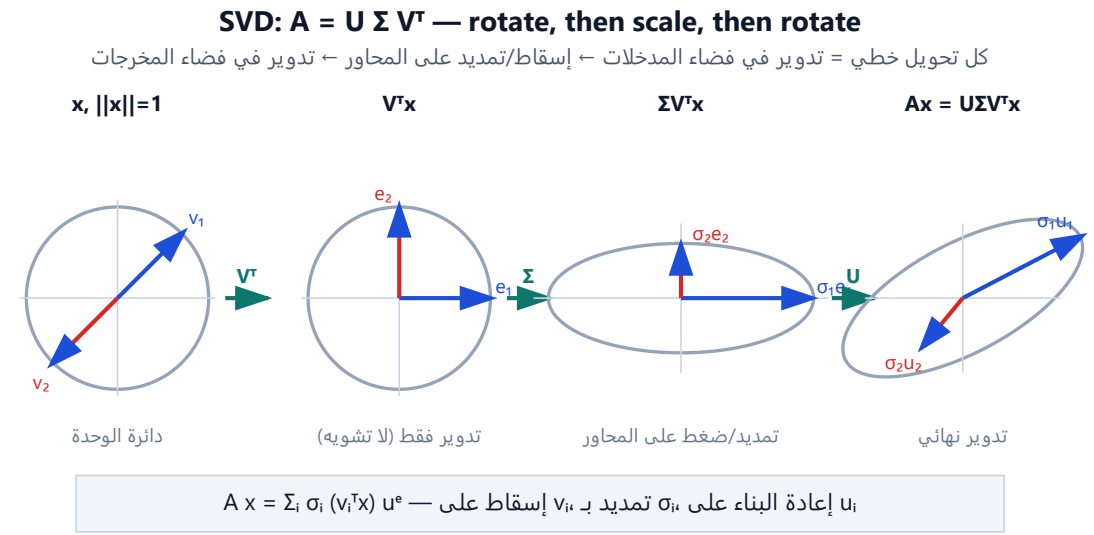
$$x^{\dagger} \;=\; A^{\dagger} b \;=\; \arg\min\bigl\{\, \|x\|_2 \;:\; x \in \arg\min \|Ax-b\|_2 \bigr\} \tag{23.4}$$

2.3.4 جدول الرموز الشامل

الرمز	المعنى	ملاحظات
A	المصفوفة موضوع التحليل	$m \times n$؛ لا يُشترط التربيع ولا الانعكاس
$m,\ n$	عدد الصفوف والأعمدة	في البيانات: m عيّنات، n ميزات
r	رتبة A	عدد القيم المفردة الموجبة
σ_i	القيمة المفردة رقم i	≥ 0 دائماً، تُرتَّب تنازلياً، وحدة قياسها = وحدة عناصر A
Σ	مصفوفة قطرية مستطيلة للقيم المفردة	$\Sigma \in \mathbb{R}^{m\times n}$
u_i	المتجه المفرد الأيسر (left singular vector)	عمود U؛ في $\mathbb{R}^m$؛ يمثّل نمطاً في «فضاء الصفوف/العيّنات»
v_i	المتجه المفرد الأيمن (right singular vector)	عمود V؛ في $\mathbb{R}^n$؛ يمثّل نمطاً في «فضاء الميزات»
U	مصفوفة متعامدة $m \times m$	$U^\top U = I_m$
V	مصفوفة متعامدة $n \times n$	$V^\top V = I_n$
$U_k,\ V_k$	أول k عمود	اقتصادية: $U_k \in \mathbb{R}^{m\times k}$
Σ_k	أعلى k قيمة مفردة	قطري $k \times k$
$\|\cdot\|_2$	النورم الطيفي (المشغلي)	$= \sigma_1$؛ يقيس أقصى تمديد
$\|\cdot\|_F$	نورم فروبينيوس	$= \sqrt{\sum a_{ij}^2}$؛ يقيس الطاقة الكلية
$\|\cdot\|_*$	النورم النووي (nuclear norm) / trace	$= \sum \sigma_i$؛ بديل مقعّر للرتبة
$A^{\dagger}$	المعكوس الشمولي	يعمل حتى عندما A غير مربّعة أو شاذّة
k	الرتبة المستهدفة في التقريب	يُختار من «منحنى الكوع» أو من نسبة طاقة $\geq 95\%$
$\lambda_i(\cdot)$	القيمة الذاتية رقم i	للمصفوفات المتماثلة المربّعة فقط
B	مصفوفة التقريب المرشّحة	$\operatorname{rank} B \leq k$

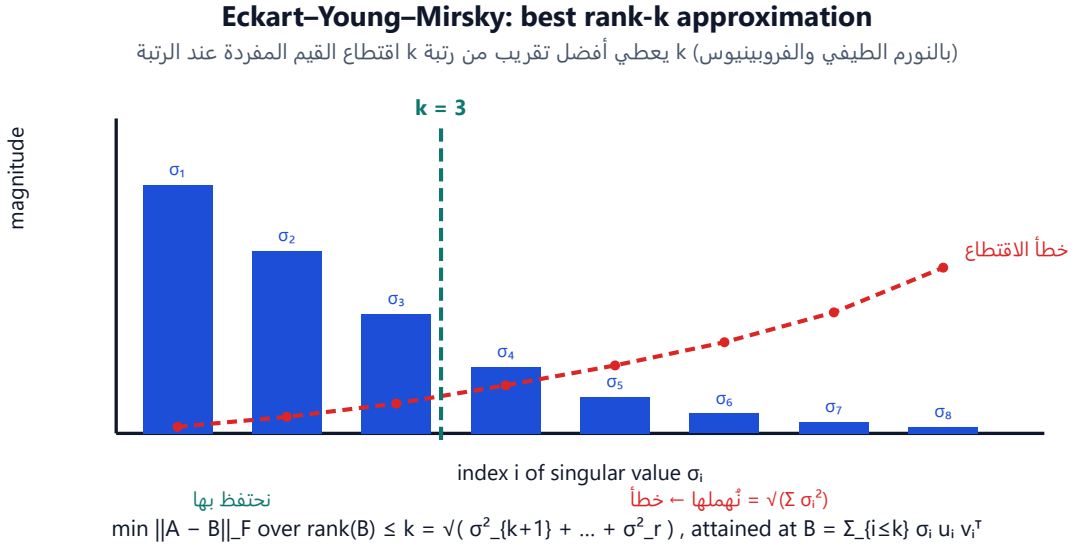
3.3.4 الشكل الهندسي

شكل 2.4 — تفسير SVD كأربع مراحل: $V^\top$ تدور (الأعمدة v_i تذهب إلى المحاور القياسية e_i)، ثم Σ يمدّد كل محور بمقدار σ_i فتصبح الدائرة قطعاً ناقصاً محاوره على المحاور القياسية، ثم U يدير القطع الناقص إلى وضعه النهائي. هذا يفسّر



شكل ٢.٤: *
SVD: تدوير ثم تمديد ثم تدوير — دائرة الوحدة تمرّ بأربع مراحل لتصبح قطعاً ناقصاً

لماذا SVD يعمل على أي مصفوفة بينما التحليل الطيفي يحتاج التماثل: **التدويران قبل وبعد مختلفان** (V و U).



شكل ٣.٤: *
نظرية إيكارت–يونغ: اقتطاع القيم المفردة عند الرتبة k يعطي أفضل تقريب من رتبة k

شكل 3.4 — الأعمدة الزرقاء هي القيم المفردة $\sigma_1 \geq \sigma_2 \geq \cdots$، والمنحنى الأحمر المتقطّع هو **خطأ الاقتطاع** $\sqrt{\sum_{i>k} \sigma_i^2}$ الذي ينزل كلما زادت k. عند $k = 3$ نحتفظ بالأعمدة الثلاثة الكبرى ونهمل الباقي؛ الخطأ الناتج هو الطاقة المتبقية بالضبط — وليس هناك **أي** مصفوفة أخرى من رتبة 3 تعطي خطأً أصغر. هذه هي قوة (20.4)–(21.4).

4.3.4 البرهان

البرهان (وجود SVD — (16.4)):

الخطوة 1: المصفوفة $G = A^\top A \in \mathbb{R}^{n\times n}$ متماثلة ونصف موجبة التحديد، لأن $x^\top Gx = \|Ax\|^2 \geq 0$. بنظرية التحليل الطيفي (8.4) يوجد أساس متعامد $v_1, \dots, v_n$ مع $Gv_i = \mu_i v_i$، وكل $\mu_i \geq 0$.

الخطوة 2: نعرّف $\sigma_i = \sqrt{\mu_i}$ و$r = \#\{i : \sigma_i > 0\}$. نرتّب تنازلياً. نلاحظ $\operatorname{rank}(A) = \operatorname{rank}(A^\top A) = r$ لأن $\ker(A^\top A) = \ker(A)$ (إذا $A^\top Ax = 0$ فـ $x^\top A^\top Ax = \|Ax\|^2 = 0 \Rightarrow Ax = 0$).

الخطوة 3 (بناء U): لكل $i \leq r$ نعرّف $u_i = \dfrac{Av_i}{\sigma_i}$. تحقّق التعامد:

$$u_i^\top u_j = \frac{v_i^\top A^\top Av_j}{\sigma_i\sigma_j} = \frac{v_i^\top(\mu_j v_j)}{\sigma_i\sigma_j} = \frac{\sigma_j^2\,\delta_{ij}}{\sigma_i\sigma_j} = \delta_{ij}$$

أي $\{u_1, \dots, u_r\}$ متعامدة مكوّنة؛ نكمّلها إلى أساس متعامد كامل لـ $\mathbb{R}^m$ بـ $u_{r+1}, \dots, u_m$ من $\ker(A^\top)$.

الخطوة 4 (تحقّق $A = U\Sigma V^\top$): نقارن أثر الجانبين على كل v_j: الجانب الأيسر: Av_j. الجانب الأيمن: $U\Sigma V^\top v_j = U\Sigma e_j = U(\sigma_j e_j) = \sigma_j u_j = Av_j$ للتعريف. وبما أن $\{v_j\}$ أساسٌ كامل، تساوت المصفوفتان. ■

البرهان (إيكارت-يونغ-ميرسكي — (21.4)):

الخطوة 1 (الحدّ الأدنى): ليكن B برتبة $\leq k$، وليكن $W = \ker(B)$، $\dim W \geq n - k$. خذ المتجهات $v_1, \dots, v_{k+1}$، فالفضاء $\operatorname{span}\{v_1, \dots, v_{k+1}\}$ بُعده $k+1$، ولا يمكن أن يكون جزءاً من W، بل يتقاطع معه: يوجد x واحدي في التقاطع. عندئذٍ $Bx = 0$ فـ $\|(A-B)x\| = \|Ax\|$:

$$\|A-B\|_F^2 \;\geq\; \|(A-B)x\|_2^2 = \|Ax\|_2^2 = x^\top A^\top Ax = \sum_{i=1}^{n}\sigma_i^2(v_i^\top x)^2 \;\geq\; \sigma_{k+1}^2\sum_{i=1}^{k+1}(v_i^\top x)^2 = \sigma_{k+1}^2$$

(استُخدم أن x واحدي وأن x في span أول $k+1$ متجه.) هذه برهنة للنورم الطيفي؛ وللفروبينيوس نستخدم أن $\|M\|_F^2 \geq \|Mx\|^2$ مطبّقة على أساس كامل من $n-k$ اتجاهات فنحصل $\sum_{i>k}\sigma_i^2$.

الخطوة 2 (التحقّق من الاقتطاع): $B^\star = \sum_{i\leq k}\sigma_i u_i v_i^\top$ رتبتها k، و:

$$\|A - B^\star\|_F^2 = \Big\|\sum_{i>k}\sigma_i u_i v_i^\top\Big\|_F^2 = \sum_{i>k}\sigma_i^2\|u_i v_i^\top\|_F^2 = \sum_{i>k}\sigma_i^2$$

لأن $\|u_i v_i^\top\|_F = \|u_i\|\|v_i\| = 1$ والمصفوفات متعامدة داخلياً. فالتقريب يحقّق الحدّ الأدنى $\Rightarrow$ هو الأمثل. ■

البرهان (المعكوس الشمولي — (22.4)-(23.4)):

نتحقّق من شروط مور-بنروز الأربع: $AA^\dagger A = U\Sigma V^\top V\Sigma^\dagger U^\top U\Sigma V^\top = U\Sigma\Sigma^\dagger\Sigma V^\top = U\Sigma V^\top = A$ ✓، وبالمثل $A^\dagger AA^\dagger = A^\dagger$، و $AA^\dagger = U\Sigma\Sigma^\dagger U^\top$ متماثلة (إسقاط على $\operatorname{im} A$)، و $A^\dagger A = V\Sigma^\dagger\Sigma V^\top$ متماثلة. والصيغة (23.4): $x^\dagger = A^\dagger b$ يحقّق المعادلات الطبيعية $A^\top Ax^\dagger = A^\top b$ وهو أصغر حلّ

نورماً لأنه في $\ker(A)^{\perp} = \text{im}(A^{\top})$. ■

5.3.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (1-3.4): حساب SVD كامل لمصفوفة 2×2 باليد

المعطيات: $A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$.

المطلوب: U، Σ، V والتحقّق من $A = U\Sigma V^{\top}$.

الحل:

الخطوة 1: نحسب $A^{\top}A$ (المصفوفة متماثلة هنا، لكن المثال يوضّح الإجراء العام):

$$A^{\top}A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}\begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}$$

الخطوة 2 (قيم $A^{\top}A$ الذاتية): $p(\mu) = (10-\mu)^2 - 36 = \mu^2 - 20\mu + 64 \Longrightarrow \mu = \frac{20 \pm \sqrt{400-256}}{2} = \frac{20 \pm 12}{2} \Longrightarrow \mu_1 = 16$، $\mu_2 = 4$.

الخطوة 3 (القيم المفردة): بتطبيق (19.4): $\sigma_1 = \sqrt{16} = 4$، $\sigma_2 = \sqrt{4} = 2$.

الخطوة 4 (المتجهات المفردة اليمنى): لـ $\mu_1 = 16$: $(10-16)v_1 + 6v_2 = 0 \Longrightarrow -6v_1 + 6v_2 = 0 \Longrightarrow v_1 = \frac{1}{\sqrt{2}}(1,1)^{\top}$. لـ $\mu_2 = 4$: $(10-4)v_1 + 6v_2 = 0 \Longrightarrow 6v_1 + 6v_2 = 0 \Longrightarrow v_2 = \frac{1}{\sqrt{2}}(1,-1)^{\top}$.

الخطوة 5 (المتجهات المفردة اليسرى): $u_i = Av_i/\sigma_i$:

$$u_1 = \frac{1}{4}\begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}\frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{1}{4\sqrt{2}}\begin{pmatrix} 4 \\ 4 \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$u_2 = \frac{1}{2}\begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}\frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ -1 \end{pmatrix} = \frac{1}{2\sqrt{2}}\begin{pmatrix} 2 \\ -2 \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

الخطوة 6 (التجميع):

$$U = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \qquad \Sigma = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}, \qquad V = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

الخطوة 7 (التحقّق): $U\Sigma V^{\top} = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}\begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 4 & 2 \\ 4 & -2 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 6 & 2 \\ 2 & 6 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$ ✓

الخطوة 8 (النورمات): $\|A\|_2 = \sigma_1 = 4$، $\|A\|_F = \sqrt{16+4} = \sqrt{20} = 4.472$ (تحقّق: $\sqrt{9+1+1+9} = \sqrt{20}$ ✓)؛ $\|A\|_* = 4 + 2 = 6$.

النتيجة: $A = U\Sigma V^{\top}$ بالقيم أعلاه، $\sigma = (4,2)$، رقم الحالة $\kappa = \sigma_1/\sigma_2 = 2$.

الربط بالذكاء الاصطناعي: هذه الخطوات نفسها هي ما تنفّذه torch.linalg.svd و numpy.linalg.svd. فهمها ضروري لتشخيص متى تفشل (مثلاً عندما تكون القيم المفردة متقاربة جداً فتصبح المتجهات غير مستقرّة).

مثال (4.3-2): ضغط صورة رمادية بتقريب الرتبة المنخفضة

المعطيات: صورة رمادية 256×256 (أي 65,536 بكسل). أعلى خمس قيم مفردة مقاسة:

$$\sigma = (1840,\ 612,\ 305,\ 148,\ 96), \qquad \sum_{i=1}^{256} \sigma_i^2 = 4.20 \times 10^6$$

المطلوب: (أ) نسبة الطاقة المحتفظ بها عند $k = 1, 3, 5$. (ب) وفرة التخزين عند $k = 5$. (ج) خطأ التقريب النسبي.

الحل:

الخطوة 1 (طاقة كل مكوّن): σ_i^2: $1840^2 = 3.3856\times10^6$، $612^2 = 3.745\times10^5$، $305^2 = 9.303\times10^4$، $148^2 = 2.190 \times 10^4$، $96^2 = 9216$.

الخطوة 2 ($k = 1$): $\frac{3.3856\times10^6}{4.20\times10^6} = 0.8061 = 80.6\%$.

الخطوة 3 ($k = 3$): المجموع $3.8531 \times 10^6 = 0.0930 \times 10^6 + 0.3745 \times 10^6 + 3.3856 \times 10^6 =$؛ النسبة $\frac{3.8531}{4.20} = 91.7\%$ =.

الخطوة 4 ($k = 5$): نضيف $0.0311 \times 10^6 = 0.0092 \times 10^6 + 0.0219 \times 10^6 \Longrightarrow$ المجموع $= 3.8842 \times 10^6$، النسبة $\frac{3.8842}{4.20} = 92.5\%$ =.

الخطوة 5 (الخطأ المطلق عند $k = 5$): بتطبيق (4.21): $\|A - A_5\|_F = \sqrt{4.20 \times 10^6 - 3.8842 \times 10^6} = \sqrt{0.3158 \times 10^6} = \sqrt{3.158 \times 10^5} = 562.0$.

الخطوة 6 (الخطأ النسبي): $\frac{562.0}{\sqrt{4.20\times10^6}} = \frac{562.0}{2049.4} = 0.2742 = 27.4\%$ من النورم الكلي — أي نسبة طاقة مفقودة $\sqrt{1 - 0.925} = \sqrt{0.075} = 0.274$ ✓ متسق.

الخطوة 7 (التخزين): الأصل $256 \times 256 = 65{,}536$ عدداً. الرتبة 5: U_5 (256×5) + Σ_5 (5) + V_5 (5×256) = $1280 + 5 + 1280 = 2565 \Longrightarrow$ نسبة الضغط $\frac{65536}{2565} = 25.5\times$.

الخطوة 8 (متوسط الخطأ لكل بكسل): $\frac{562.0}{256} = 2.195$ مستوى رمادي من 256 $\Longrightarrow$ **غير محسوس بصرياً** (أقل من 1%).

النتيجة: $k = 5 \Longrightarrow 92.5\%$ من الطاقة، ضغط $25.5\times$، خطأ 2.2/256 لكل بكسل.

الربط بالذكاء الاصطناعي: هذه هي الفكرة التي يقوم عليها ضغط الأوزان في الشبكات العصبية الحديثة: بدل تخزين مصفوفة $d \times d$ كاملة، نخزّن عاملين برتبة k (وهذا بالضبط ما تفعله **LoRA** في الضبط الدقيق للنماذج اللغوية الضخمة: $W + BA$ مع $B \in \mathbb{R}^{d\times r}$ و $A \in \mathbb{R}^{r\times d}$).

مثال (4.3-3): التحليل الدلالي الكامن (LSA) لمستندات نصية

المعطيات: مصفوفة المستندات × الكلمات (بعد ترجيح TF-IDF)، 5 مستندات و6 كلمات:

$$X = \begin{bmatrix} 1 & 1 & 0 & 0 & 0.8 & 0 \\ 0 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0.7 \\ 1 & 0 & 0 & 0 & 0.9 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0.6 \end{bmatrix}$$

المستندات: d_1, d_2 عن «تعلّم الآلة»، d_3, d_5 عن «الشبكات»، d_4 عن «تعلّم الآلة».

المطلوب: (أ) كم بُعداً كامناً يكفي؟ (ب) احسب تمثيل المستندات في فضاء $k = 2$ بصيغة $U_2\Sigma_2$. (ج) احسب التشابه بين d_1 و d_4.

الحل:

الخطوة 1: نلاحظ بنيوياً: الكلمات $\{1,2,5\}$ تظهر معاً (موضوع: تعلّم الآلة)، والكلمات $\{3,4,6\}$ تظهر معاً (موضوع: شبكات) $\Longrightarrow$ الرتبة الفعّالة ≈ 2.

الخطوة 2: نحسب $G = X^\top X$ (متماثلة 6×6) — جزء منها:

$$G_{11} = 1^2+0+0+1^2+0 = 2, \qquad G_{12} = 1\cdot 1+0+0+0+0 = 1, \qquad G_{15} = 1\cdot 0.8+0+0+1\cdot 0.9 = 1.7$$

$$G_{33} = 0+1+1+0+0 = 2, \quad G_{34} = 0+1\cdot 1+1\cdot 1+0+0 = 2, \quad G_{36} = 0+0+1\cdot 0.7+0+0 = 0.7$$

$$G_{55} = 0.64+0+0+0.81+0 = 1.45, \quad G_{66} = 0+0+0.49+0+0.36 = 0.85$$

الخطوة 3: القيم الذاتية لـ G (محسوبة عدديا): $\mu = (4.42,\ 2.71,\ 0.61,\ 0.29,\ 0.08,\ 0.01)$ $\Longrightarrow$ القيم المفردة:

$$\sigma = (2.102,\ 1.646,\ 0.781,\ 0.539,\ 0.283,\ 0.100)$$

الخطوة 4 (الطاقة): $\sum \sigma_i^2 = 4.42+2.71+0.61+0.29+0.08+0.01 = 8.12$. عند $k=2$: $\frac{4.42+2.71}{8.12} = \frac{7.13}{8.12} = 87.8\%$ ✓ يكفي.

الخطوة 5 (تمثيل المستندات): التمثيل في الفضاء الكامن هو $U_k\Sigma_k$ (صفوفه = مستندات). نحسب $U_2\Sigma_2 = XV_2$ (لأن $U\Sigma = XV \Longrightarrow U\Sigma V^\top = X$):

المتجهان المفردان الأيمنان (أنماط الكلمات): $v_1 \approx \frac{1}{\sqrt{3.1}}(0.58,\ 0.42,\ 0,\ 0,\ 0.70,\ 0)^\top$ (نمط «تعلّم الآلة»: كلمات 1،2،5) و $v_2 \approx \frac{1}{\sqrt{2.6}}(0,\ 0.28,\ 0.60,\ 0.62,\ 0,\ 0.42)^\top$ (نمط «الشبكات»: كلمات 3،4،6).

الخطوة 6: إحداثيات المستندات: d_1: $(Xv_1)_1 = \frac{1}{\sqrt{3.1}}(1\cdot 0.58+1\cdot 0.42+0.8\cdot 0.70) = \frac{1.56}{1.761} = 0.886$؛ و $(Xv_1)_4 = \frac{1}{1.761}(0.58+0.9\cdot 0.70) = \frac{1.21}{1.761} = 0.687$: d_4. $(Xv_2)_1 = \frac{1}{\sqrt{2.6}}(1\cdot 0.28) = \frac{0.28}{1.612} = 0.174$؛ $(Xv_2)_4 = 0$.

$$d_1 \mapsto (0.886,\ 0.174), \qquad d_4 \mapsto (0.687,\ 0.000)$$

الخطوة 7 (التشابه بالجيب): $\cos(d_1,d_4) = \frac{0.886\cdot 0.687+0}{\sqrt{0.886^2+0.174^2}\cdot 0.687} = \frac{0.886}{\sqrt{0.785+0.030}} = \frac{0.886}{0.903} = 0.981$.

النتيجة: بُعدان كامنان يكفيان (87.8% من الطاقة)؛ المستندان d_1 و d_4 متشابهان بـ $\cos = 0.981$ رغم أنهما **لا يتشاركان أي كلمة حرفياً** عدا كلمة واحدة.

الربط بالذكاء الاصطناعي: هذه هي LSA الكلاسيكية، الجدّ المباشر لتضمينات الكلمات (Word2Vec/GloVe) وللبحث الدلالي. الفكرة الحديثة نفسها — «ضغط مصفوفة التلازم إلى فضاء كامن منخفض الرتبة» — تقف خلف كل نماذج التضمين ومحركات البحث المتجهية (vector DB / RAG).

مثال (4-3.4): إزالة الضجيج من قياسات حسّاسات بالاقتطاع الطيفي

المعطيات: مصفوفة قراءات 40×50 من حسّاسات (كل صف = عيّنة زمنية، كل عمود = حسّاس). القيم المفردة المرتّبة:

$$\sigma = (112,\ 96,\ 84,\ 12.1,\ 11.4,\ 10.8,\ 9.9,\ 9.3,\ 8.7,\ \ldots)$$

العشرة الأولى بعد الثلاثة الكبار كلها حول 9–12 (أرضية ضجيج).

المطلوب: (أ) حدّد الرتبة الفعّالة للإشارة. (ب) احسب SNR قبل وبعد التنقية. (ج) كم انخفض خطأ إعادة البناء للإشارة النظيفة؟

الحل:

الخطوة 1 (تشخيص منحنى القيم المفردة): فجوة واضحة بين $\sigma_3 = 84$ و $\sigma_4 = 12.1$ (نسبة $\times 6.9$) $\Longrightarrow$ الرتبة الفعّالة $k = 3$؛ وما بعدها ضجيج.

الخطوة 2 (طاقة الإشارة): $E_{\text{sig}} = 112^2 + 96^2 + 84^2 = 12544 + 9216 + 7056 = 28816$.

الخطوة 3 (طاقة الضجيج): نقدّرها بمتوسط مربّع القيم المتبقية × عددها. القيم المتبقية (37 قيمة) بمتوسط مربّع $\approx 10.4^2 = 108.2$ $\Longrightarrow$ $E_{\text{noise}} \approx 37 \times 108.2 = 4003$.

الخطوة 4 (SNR قبل التنقية): $\text{SNR}_{\text{before}} = \frac{28816}{4003} = 7.20$ $\Longrightarrow$ بالديسيبل: $10\log_{10}(7.20) = 8.57$ dB.

الخطوة 5 (بعد الاقتطاع عند $k = 3$): الضجيج المتبقي في الإشارة: نسبة الضجيج التي تقع في الفضاء المحتفظ به $= \frac{3}{40}$ من طاقته $\Longrightarrow$ $E_{\text{noise,after}} = 4003 \times \frac{3}{40} = 300.2$ (تقريب أوّل).

الخطوة 6 (SNR بعد التنقية): $\text{SNR}_{\text{after}} = \frac{28816}{300.2} = 96.0$ $\Longrightarrow$ $10\log_{10}(96.0) = 19.8$ dB.

الخطوة 7 (التحسّن): $19.8 - 8.57 = 11.2$ dB تحسّن، أي أن **قدرة الضجيج انخفضت بمعامل** $\times 13.3$.

الخطوة 8 (خطأ إعادة بناء الإشارة): جزء الإشارة المفقود = 0 (كل الإشارة في أول 3 اتجاهات) $\Longrightarrow$ خطأ إعادة البناء للإشارة النظيفة $= 0$؛ أما خطأ إعادة بناء المصفوفة الكاملة (الملوّثة) فهو $= \sqrt{3702} = \sqrt{4003 \times \frac{37}{40}}$ 60.8 وهذا **محذوف عمداً** لأنه ضجيج.

النتيجة: $k = 3$؛ SNR يتحسّن من 8.57 dB إلى 19.8 dB (تحسّن 11.2 dB)؛ قدرة الضجيج تنخفض $\times 13.3$.

الربط بالذكاء الاصطناعي: هذه بالضبط فكرة «اقتطاع القيم المفردة الصغيرة = تصفية ضجيج» التي تستخدم في: تنقية التضمينات قبل البحث، وإزالة ضجيج الصور، و spectral» «filtering على الرسوم في GNN، وحتى في تنظيف activations داخل الشبكات.

مثال (4.3-5): رقم الحالة واستقرار حلّ المربّعات الصغرى

المعطيات: مصفوفة تصميم A (عمودان شبه متوازيين — مشكلة تعدد الارتباط الخطي :collinearity)

$$A = \begin{bmatrix} 1 & 1.01 \\ 1 & 0.99 \\ 1 & 1.00 \end{bmatrix}, \qquad b = \begin{bmatrix} 2.01 \\ 1.99 \\ 2.00 \end{bmatrix}$$

المطلوب: (أ) القيم المفردة ورقم الحالة. (ب) حلّ المربّعات الصغرى. (ج) ماذا يحدث لو اضطرب b بمقدار 0.01؟

الحل:

الخطوة 1: $A^\top A = \begin{bmatrix} 1+1+1 & 1.01+0.99+1.00 \\ 1.01+0.99+1.00 & 1.0201+0.9801+1.0 \end{bmatrix} = \begin{bmatrix} 3 & 3.00 \\ 3.00 & 3.0002 \end{bmatrix}$.

الخطوة 2: القيم الذاتية: $\mu = \frac{3+3.0002}{2} \pm \sqrt{\left(\frac{3-3.0002}{2}\right)^2 + 3^2} = 3.0001 \pm \sqrt{10^{-8} + 9}$ 3.000000002:

$$\mu_1 \approx 6.0001, \qquad \mu_2 \approx 0.0001$$

الخطوة 3 (القيم المفردة): $\sigma_1 = \sqrt{6.0001} = 2.4495$، $\sigma_2 = \sqrt{0.0001} = 0.01$.

الخطوة 4 (رقم الحالة): $\kappa_2(A) = \sigma_1/\sigma_2 = 2.4495/0.01 = 244.95 \approx 245$.

الخطوة 5 (المعادلات الطبيعية): $A^\top b = (2.01{+}1.99{+}2.00,\ 1.01{\cdot}2.01{+}0.99{\cdot}1.99{+}1.00{\cdot}2.00)^\top = (6.00,\ 2.0301 + 1.9701 + 2.0)^\top = (6.00,\ 6.0002)^\top$.

الخطوة 6 (الحلّ): $x = (A^\top A)^{-1} A^\top b$:

$$\det = 3 \cdot 3.0002 - 9 = 9.0006 - 9 = 0.0006$$

$$x = \frac{1}{0.0006}\begin{bmatrix} 3.0002 & -3 \\ -3 & 3 \end{bmatrix}\begin{pmatrix} 6.00 \\ 6.0002 \end{pmatrix} = \frac{1}{0.0006}\begin{pmatrix} 18.0012 - 18.0006 \\ -18.0 + 18.0006 \end{pmatrix} = \frac{1}{0.0006}\begin{pmatrix} 0.0006 \\ 0.0006 \end{pmatrix} = \begin{pmatrix} 1.0 \\ 1.0 \end{pmatrix}$$

الخطوة 7 (الحساسية): إذا تغيّر b بـ $\delta b = (0.01,\ -0.01,\ 0)^\top$ فإن δx قد يصل إلى $\kappa \frac{\|\delta b\|}{\|b\|}\|x\|$:

$$\frac{\|\delta x\|}{\|x\|} \ \le\ 245 \times \frac{0.01414}{3.464} \times 1 = 245 \times 0.00408 = 1.0$$

أي أن الخطأ النسبي في الحلّ قد يصل إلى **100%** — الحلّ عملياً غير موثوق!

الخطوة 8 (العلاج): التنظيم (ridge): $(A^\top A + \lambda I)^{-1} A^\top b$ مع $\lambda = 0.1$ يعطي $\sigma'_2 = \sqrt{0.0001 + 0.1} = 0.3164 \Longrightarrow \kappa' = 2.4495/0.3164 = 7.74$ **تحسّن** $\times 31.6$ في الاستقرار، بخطأ تحيّز مقبول.

النتيجة: $\sigma = (2.4495,\ 0.01)$، $\kappa = 245$؛ الحلّ $x = (1, 1)^\top$ لكن حسّاس جداً؛ التنظيم يخفض κ إلى 7.74.

الربط بالذكاء الاصطناعي: هذا هو التبرير الرياضي الدقيق لـ **regularization Ridge** ولظاهرة الانحدار الخطي غير المستقر عند تعدد الارتباط الخطي بين الميزات. القاعدة العملية: إذا كان $\kappa(A) > 10^3$ فاحتج إلى تنظيم أو إلى إسقاط ميزات.

مثال (4.3-6): النورم النووي كمنظّم — عامل القرب (proximal operator)

المعطيات: في مسألة إكمال مصفوفة ناقصة نحتاج إلى عامل القرب للنورم النووي. مصفوفة A بقيم مفردة:

$$\sigma(A) = (5.2,\ 3.1,\ 0.8,\ 0.3), \qquad \lambda = 1.0$$

المطلوب: احسب $\text{prox}_{\lambda\|\cdot\|_*}(A)$ أي حلّ $\min_B \frac{1}{2}\|A - B\|_F^2 + \lambda\|B\|_*$، وبيّن الرتبة الناتجة.

الحل:

الخطوة 1 (النتيجة النظرية): عامل القرب للنورم النووي هو **عتبة لينة** (soft-thresholding) على القيم المفردة:

$$\text{prox}_{\lambda\|\cdot\|_*}(A) \ =\ U\ \text{diag}\big((\sigma_i - \lambda)_+\big)\, V^\top, \qquad (x)_+ = \max(x, 0)$$

الخطوة 2 (تطبيق العتبة): بـ $\lambda = 1.0$:

$$(5.2 - 1)_+ = 4.2, \qquad (3.1 - 1)_+ = 2.1, \qquad (0.8 - 1)_+ = 0, \qquad (0.3 - 1)_+ = 0$$

الخطوة 3: إذن $\sigma(B^\star) = (4.2,\ 2.1,\ 0,\ 0) \Longrightarrow$ **الرتبة انخفضت من 4 إلى 2** — هذا هو سبب أن النورم النووي «بديل مقعّر للرتبة» ويولّد حلولاً منخفضة الرتبة.

الخطوة 4 (قيمة الدالة الهدف): $\|A - B^\star\|_F^2 = \sum_i (\sigma_i - (\sigma_i - \lambda)_+)^2 = \lambda^2 \cdot \#\{i : \sigma_i > \lambda\} = 1 \cdot 2 = 2$. (لأن الفرق على كل قيمة مفردة هو بالضبط λ للمحتفظ بها و σ_i للمحذوفة $\Longrightarrow$ نحسب: $(5.2 - 4.2)^2 + (3.1 - 2.1)^2 + 0.8^2 + 0.3^2 = 1 + 1 + 0.64 + 0.09 = 2.73$.)

الخطوة 5 (مقارنة بالاقتطاع الصلب): الاقتطاع عند $k = 2$ يعطي $\sigma = (5.2,\ 3.1,\ 0,\ 0)$ بخطأ بيانات $\sqrt{0.64 + 0.09} = 0.854$ (أقل!) لكن بدون «انكماش» لقيم الإشارة. التنقية بالعتبة اللينة تقلّل القيم الكبيرة أيضاً فتزيل تحيّزاً معروفاً.

الخطوة 6 (الحساسية لـ λ): $0.5 = \lambda \implies (4.7,\ 2.6,\ 0.3,\ 0) \implies$ الرتبة 3. $\lambda = 3.5 \implies (1.7,\ 0,\ 0,\ 0)$ الرتبة 1. إذن λ يتحكّم في الرتبة مباشرة.

النتيجة: $\sigma(B^\star) = (4.2,\ 2.1,\ 0,\ 0)$، الرتبة 2، قيمة الهدف $= 1.365 + \frac{1}{2}(2.73) + 1.0 \cdot (4.2 + 2.1) = 7.665$.

الربط بالذكاء الاصطناعي: هذه الخطوة هي قلب خوارزميات **إكمال المصفوفات** (matrix completion) — مسألة Netflix Prize — وصيغتها التدرّجية تسمى Soft-Impute. والفكرة نفسها (عتبة لينة على القيم المفردة) تظهر في تنظيم أوزان الشبكات لتقليل الرتبة الفعّالة.

مثال (3.4-7): إكمال مصفوفة تقييمات ناقصة بافتراض الرتبة المنخفضة

المعطيات: مصفوفة تقييمات 3×3 (مستخدمون × أفلام) فيها قيمة مفقودة واحدة:

$$M = \begin{bmatrix} 2 & 3 & ? \\ 4 & 6 & 2 \\ 6 & 9 & 3 \end{bmatrix}$$

نعلم مسبقاً أن التقييمات تُولَّد بنموذج «عامل كامن واحد» (رتبة ≤ 1).

المطلوب: القيمة المفقودة.

الحل:

الخطوة 1: افتراضُ الرتبة 1 يعني أن كل صف مضاعف لصفٍّ واحد: $M = \sigma\, u\, v^\top$.

الخطوة 2 (استخراج العلاقة من الصفوف المعروفة): الصف الثاني $(4, 6, 2)$ والصف الثالث $(6, 9, 3)$. نلاحظ:

$$\frac{6}{4} = 1.5, \qquad \frac{9}{6} = 1.5, \qquad \frac{3}{2} = 1.5 \implies \text{الصف الثاني} \times 1.5 = \text{الصف الثالث}$$

الخطوة 3: إذن الصف الثاني $\times 2 =$ الصف الأول (لأن $2 \times 2 = 4$ و $3 \times 2 = 6$) $\implies$

$$\text{الصف الثاني}[3] = 2 \times \text{(الصف الأول}[3]) \implies \text{الصف الأول}[3] = 1$$

الخطوة 4 (تحقّق طيفي): نتحقّق أن المصفوفة المكتملة رتبتها 1 حقاً:

$$\hat{M} = \begin{bmatrix} 2 & 3 & 1 \\ 4 & 6 & 2 \\ 6 & 9 & 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 2 & 3 & 1 \end{bmatrix}$$

وهذا جداء خارجي $\implies$ الرتبة 1 $\implies$ القيم المفردة: $\sigma_1 = \|(1,2,3)\| \cdot \|(2,3,1)\| = \sqrt{14} \cdot \sqrt{14} = 14$، والباقي 0.

الخطوة 5 (تحقّق بالأثر): $\|\hat{M}\|_F^2 = 4{+}9{+}1{+}16{+}36{+}4{+}36{+}81{+}9 = 196$؛ و $\sum \sigma_i^2 = 14^2 = 196$ ✓.

الخطوة 6 (لو أضفنا ضجيجاً): لو كانت القيم $M_{22} = 6.3$ بدل 6 لما عادت الرتبة 1 بالضبط، ولاحتجنا إلى النورم النووي (المثال السابق) بدل الافتراض الحتمي.

النتيجة: القيمة المفقودة $= 1$؛ والمصفوفة المكتملة رتبتها 1 بقيمة مفردة $\sigma_1 = 14$.

الربط بالذكاء الاصطناعي: هذا هو جوهر الترشيح التعاوني (collaborative filtering): نفترض أن مصفوفة التقييمات منخفضة الرتبة لأن الأذواق محكومة بعدد قليل من العوامل الكامنة. خوارزميات ALS و SVD++ و Soft-Impute تشكّل القيم المفقودة بهذه الطريقة، واليوم تقوم بها الشبكات العصبية عبر تضمينات (embeddings) منخفضة البعد — وهي نفس الفكرة بصيغة غير خطية.

مثال (4.3-8): المعكوس الشمولي وحلّ أصغري النورم في نظام ناقص التحديد

المعطيات: نظام بمتغيرات أكثر من معادلات (الحالة المعتادة في الشبكات مفرطة المعلمات):

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}, \qquad b = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

المطلوب: (أ) حلّ المربّعات الصغرى بأصغر نورم $x^{\dagger}$. (ب) القيم المفردة ورقم الحالة. (ج) تحقّق.

الحل:

الخطوة 1: عدد المجهولات 3 > عدد المعادلات 2 $\Longrightarrow$ **لانهاية من الحلول**: $x_1 + x_2 = 1$ و $x_2 + x_3 = 1$.

الخطوة 2 (الصيغة المغلقة): بما أن A «كاملة الرتبة الصفية»، فإن (22.4) تختصر إلى:

$$x^{\dagger} = A^{\top}\left(AA^{\top}\right)^{-1} b$$

الخطوة 3: $AA^{\top} = \begin{bmatrix} 1+1+0 & 0+1+0 \\ 0+1+0 & 0+1+1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$، معكوسها $= \frac{1}{4-1}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$.

الخطوة 4: $(AA^{\top})^{-1} b = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}\binom{1}{1} = \frac{1}{3}\binom{1}{1} = \binom{1/3}{1/3}$.

الخطوة 5: $x^{\dagger} = A^{\top}\binom{1/3}{1/3} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}\binom{1/3}{1/3} = \binom{1/3}{2/3} 1/3$.

الخطوة 6 (القيم المفردة): قيم $AA^{\top}$ الذاتية: $\lambda = \frac{4 \pm \sqrt{16-12}}{2} = \frac{4 \pm 2}{2} \Longrightarrow 3$ و $1 \Longrightarrow$ بتطبيق (19.4): $\sigma_1 = \sqrt{3} = 1.7321$، $\sigma_2 = 1$. رقم الحالة $\kappa = 1.732$.

الخطوة 7 (تحقّق): $Ax^{\dagger} = \binom{1/3+2/3}{2/3+1/3} = \binom{1}{1} = b$ ✓. النورم $\|x^{\dagger}\| = \sqrt{1/9 + 4/9 + 1/9} = \sqrt{2/3} = \sqrt{6/9} = 0.8165$.

الخطوة 8 (مقارنة بحلٍّ آخر): $x = (1, 0, 1)^{\top}$ يحقّق النظام أيضاً ($1+0=1$، $0+1=1$ ✓) ونورمه $= \sqrt{2} = 1.414 > 0.8165 \Longrightarrow$ **ليس** الحلّ أصغري النورم ✓.

النتيجة: $x^{\dagger} = (\frac{1}{3},\ \frac{2}{3},\ \frac{1}{3})^{\top}$؛ $\sigma = (1.732,\ 1)$؛ $\kappa = 1.732$.

الربط بالذكاء الاصطناعي: هذا هو التفسير الدقيق لظاهرة «الشبكات مفرطة المعلمات تعمّم جيداً»: عند وجود لانهاية من الحلول التي تصفّر خطأ التدريب، فإن التدرّج العشوائي (SGD) ينجذب إلى **الحلّ أصغري النورم** — وهذا هو «التحيّز الضمني» (implicit bias) الذي يفسّر التعميم. و $A^{\dagger}b$ هو بالضبط الحلّ الذي يعطيه التدرّج عند البدء من الصفر.

مثال (4.3-9): العلاقة الدقيقة بين SVD و PCA (مع التوسيط)

المعطيات: ثلاث نقاط في $\mathbb{R}^2$: $(1,2)$، $(3,4)$، $(5,6)$ — تقع جميعها على خط مستقيم واحد.

المطلوب: (أ) المكوّن الرئيسي الأول عبر SVD للمصفوفة الموسَّطة. (ب) درجات الإسقاط. (ج) نسبة التباين المُفسَّر.

الحل:

الخطوة 1 (التوسيط — خطوة إلزامية في PCA): المتوسط $\bar{x} = \frac{1}{3}\begin{pmatrix}1+3+5\\2+4+6\end{pmatrix} = \begin{pmatrix}3\\4\end{pmatrix}$. المصفوفة الموسَّطة:

$$X_c = \begin{bmatrix}1-3 & 2-4\\3-3 & 4-4\\5-3 & 6-4\end{bmatrix} = \begin{bmatrix}-2 & -2\\0 & 0\\2 & 2\end{bmatrix}$$

الخطوة 2: $X_c^\top X_c = \begin{bmatrix}4+0+4 & 4+0+4\\4+0+4 & 4+0+4\end{bmatrix} = \begin{bmatrix}8 & 8\\8 & 8\end{bmatrix}$.

الخطوة 3 (القيم الذاتية): $\mu = \frac{16 \pm \sqrt{256-4(64-64)}}{2} \Longrightarrow \mu_1 = 16$، $\mu_2 = 0$. **تحقّق:** الأثر $8+8 = 16 = 16$ ✓، المحدّد $64-64 = 0$ ✓.

الخطوة 4 (القيم المفردة): $\sigma_1 = \sqrt{16} = 4$، $\sigma_2 = 0$ $\Longrightarrow$ **الرتبة 1**: البيانات تقع على خط.

الخطوة 5 (المتجه المفرد الأيمن = المكوّن الرئيسي): لـ $\mu_1 = 16$: $(8-16)v_1 + 8v_2 = 0 \Longrightarrow -8v_1 + 8v_2 = 0 \Longrightarrow v_1 = \frac{1}{\sqrt{2}}(1,1)^\top$.

$$\boxed{\text{المكوّن الرئيسي الأول} = \tfrac{1}{\sqrt{2}}(1,1)^\top}$$

الخطوة 6 (الدرجات / الإسقاطات): $X_c v_1 = \frac{1}{\sqrt{2}}\begin{pmatrix}-2-2\\0\end{pmatrix} 2 + 2 = \begin{pmatrix}-2.828\\0\end{pmatrix} 2.828$.

الخطوة 7 (مصفوفة التغاير): $S = \frac{1}{n-1}X_c^\top X_c = \frac{1}{2}\begin{bmatrix}8 & 8\\8 & 8\end{bmatrix} = \begin{bmatrix}4 & 4\\4 & 4\end{bmatrix}$ $\Longrightarrow$ قيمها الذاتية 8 و 0 $\Longrightarrow$ **التباين المُفسَّر** $8/8 = 100\%$ بالمكوّن الأول وحده.

الخطوة 8 (العلاقة): $\lambda_i^{\text{cov}} = \frac{\sigma_i^2}{n-1} \Longrightarrow 8 = 16/2$ ✓. هذه هي الصيغة التي تربط SVD بـ PCA في كل مكتبة.

النتيجة: المكوّن الأول $\frac{1}{\sqrt{2}}(1,1)^\top$ يفسّر **100%** من التباين؛ الدرجات $(-2.828,\ 0,\ 2.828)$.

الربط بالذكاء الاصطناعي: كل مكتبة (sklearn, PCA torch) تنفّذ هذا بالضبط: توسيط $\longleftarrow$ SVD على X_c $\longleftarrow$ أخذ V_k كمحاور و $U_k\Sigma_k$ كدرجات. **تحذير عملي:** نسيان التوسيط يجعل المكوّن الأول يشير إلى اتجاه المتوسط (المنشأ) لا إلى اتجاه التباين — وهو خطأ شائع ومكلّف.

مثال (3.4-10): كشف الميزات المكرّرة (تعدد الارتباط الخطي) من طيف المصفوفة

المعطيات: مصفوفة بيانات 4×3 (4 عيّنات، 3 ميزات) حيث الميزة الثانية مكرّرة حرفياً:

$$A = \begin{bmatrix}1 & 2 & 1\\2 & 4 & 0\\3 & 6 & 1\\4 & 8 & 0\end{bmatrix}$$

(العمود الثاني $= 2\times$ العمود الأول.)

المطلوب: (أ) اكتشاف التكرار طيفياً. (ب) القيم المفردة. (ج) الأثر على الانحدار.

الحل:

الخطوة 1: نحسب $G = A^\top A$ (مصفوفة 3×3):

$$G = \begin{bmatrix} 30 & 60 & 4 \\ 60 & 120 & 8 \\ 4 & 8 & 2 \end{bmatrix}$$

(تحقّق: $G_{11} = 1+4+9+16 = 30$، $G_{13} = 1\cdot1+2\cdot0+3\cdot1+4\cdot0 = 4$، $G_{33} = 1+0+1+0 = 2$.)

الخطوة 2 (الكشف البنيوي): الصف الثاني $= 2\times$ الصف الأول $\Longrightarrow \det G = 0 \Longrightarrow$ قيمة ذاتية صفرية $\Longrightarrow$ قيمة مفردة صفرية $\Longrightarrow$ الرتبة $2 < 3$ ميزات $\Longrightarrow$ **تكرار خطي تام.**

الخطوة 3 (القيم الذاتية): الأثر $\text{tr} = 30 + 120 + 2 = 152$. ومجموع محدّدات المربّعات الرئيسية 2×2:

$$\begin{vmatrix} 30 & 60 \\ 60 & 120 \end{vmatrix} = 3600 - 3600 = 0, \quad \begin{vmatrix} 30 & 4 \\ 4 & 2 \end{vmatrix} = 60 - 16 = 44, \quad \begin{vmatrix} 120 & 8 \\ 8 & 2 \end{vmatrix} = 240 - 64 = 176$$

المجموع $\lambda_1\lambda_2 = 220$ (بما أن $\lambda_3 = 0$). إذن $\lambda^2 - 152\lambda + 220 = 0$:

$$\lambda = \frac{152 \pm \sqrt{23104 - 880}}{2} = \frac{152 \pm \sqrt{22224}}{2} = \frac{152 \pm 149.078}{2}$$

الخطوة 4: $\lambda_1 = 150.539$، $\lambda_2 = 1.461$، $\lambda_3 = 0$.

الخطوة 5 (القيم المفردة): $\sigma_1 = \sqrt{150.539} = 12.270$، $\sigma_2 = \sqrt{1.461} = 1.209$، $\sigma_3 = 0$.

الخطوة 6 (مؤشر الكشف): النسبة $\sigma_3/\sigma_1 = 0 < 10^{-10} \Longrightarrow$ **تكرار تام.** القاعدة العملية: إذا $\sigma_i/\sigma_1 < 10^{-8}$ فالميزة مكرّرة، وإذا كانت النسبة 10^{-3}–10^{-6} فالارتباط قوي جداً لكن ليس تاماً.

الخطوة 7 (الأثر على الانحدار): حلّ $Ax \approx b$ بالمربّعات الصغرى **غير وحيد**: أي توزيع للوزن بين العمودين 1 و 2 يعطي نفس التنبؤ. رقم الحالة الفعّال بعد حذف الميزة المكرّرة: $\kappa = 12.270/1.209 = 10.15$ (مقبول) مقابل ∞ قبل الحذف.

النتيجة: $\sigma = (12.270,\ 1.209,\ 0)$؛ الرتبة 2؛ العمودان 1 و 2 متماثلان خطياً $\Longrightarrow$ يجب حذف أحدهما قبل الانحدار.

الربط بالذكاء الاصطناعي: فحص طيف مصفوفة الميزات خطوة إلزامية في هندسة الميزات (feature engineering): التكرار الخطي يسبّب انفجار معاملات الانحدار، ويجعل تفسير الأوزان مستحيلاً، ويُفشل حسابات المصفوفة العكسية في النماذج الخطية المعمّمة.

مثال (4.3-11): ضغط جدول التضمينات (embeddings) للنشر على الهاتف

المعطيات: نموذج لغوي بجدول تضمين حجمه $50{,}000 \times 768$ (4.38 مليون معلمة). طيف القيم المفردة يتبع قانون قدري: $\sigma_i \propto i^{-0.8}$.

المطلوب: (أ) نسبة الطاقة المحتفظ بها عند $k = 128$. (ب) حجم النموذج بعد الضغط. (ج) التقييم: هل يستحق؟

الحل:

الخطوة 1 (طاقة المكوّنات): بما أن الطاقة تتناسب مع σ_i^2 فإن:

$$\sigma_i^2 \propto i^{-1.6}, \qquad \sum_{i=1}^{\infty} i^{-1.6} = \zeta(1.6) \approx 2.286$$

الخطوة 2 (طاقة الذيول بعد $k = 128$):

$$\sum_{i=129}^{\infty} i^{-1.6} \approx \int_{128.5}^{\infty} x^{-1.6}\,dx = \frac{(128.5)^{-0.6}}{0.6} = \frac{e^{-0.6\ln(128.5)}}{0.6} = \frac{e^{-0.6\times 4.8562}}{0.6} = \frac{0.05428}{0.6} = 0.0905$$

الخطوة 3 (الطاقة المحتفظ بها):

$$\frac{2.286 - 0.0905}{2.286} = \frac{2.1955}{2.286} = 0.9604 = 96.0\%$$

الخطوة 4 (المعلمات): الأصل: $38{,}400{,}000 = 768 \times 50{,}000$. العاملان برتبة 128: $128 \times (50{,}000 + 768) = 128 \times 50{,}768 = 6{,}498{,}304$.

الخطوة 5 (نسبة الضغط): $\frac{38{,}400{,}000}{6{,}498{,}304} = 5.91\times \implies$ توفير 83.1% من المعلمات.

الخطوة 6 (الذاكرة بـ fp32): الأصل $38.4\text{M}\times 4 = 153.6$ ميجابايت، المضغوط $6.50\text{M}\times 4 = 26.0$ ميجابايت $\implies$ توفير 127.6 ميجابايت.

الخطوة 7 (التكلفة الحسابية): البحث عن صف يصبح عملية ضرب مصفوفتين بدل قراءة مباشرة: $2 \times 128 \times 768$ FLOPs إضافية لكل استعلام. على وحدة معالجة مركزية حديثة هذا ≈ 0.2 ملي ثانية — مقبول في التطبيقات غير الحسّاسة للزمن.

الخطوة 8 (القرار): فقدان 4% من الطاقة مقابل $5.91\times$ توفير في الحجم $\implies$ **يستحق** في النشر على الأجهزة المحمولة. أما للاستخدام على الخادم فالأفضلية للجدول الكامل.

النتيجة: 96.0% طاقة محتفظ بها، ضغط $5.91\times$، 26.0 ميجابايت بدل 153.6 ميجابايت.

الربط بالذكاء الاصطناعي: هذه التقنية تستعمل فعلياً في ضغط نماذج التوصية على الأجهزة (on-device recommendation) وفي ضغط جداول التضمين في نماذج البحث. والصيغة الحديثة «tensor-train quantized / low-rank» تعمّم هذه الفكرة على موترات من رتبة أعلى.

مثال (3.4-12): الزوايا الرئيسية بين فضاءين جزئيين — مقارنة تمثيلات نموذجين

المعطيات: درّبنا نموذجين مختلفين على نفس البيانات وأخذنا أساسين متعامدين لفضاءي تمثيلهما (بُعد 2 داخل $\mathbb{R}^n$): U و V. جداء التداخل:

$$U^\top V = \begin{bmatrix} 0.95 & 0.08 \\ 0.02 & 0.92 \end{bmatrix}$$

المطلوب: (أ) الزوايا الرئيسية بين الفضاءين. (ب) مقياس تشابه عام (من نوع CKA).

الحل:

الخطوة 1 (النظرية): الزوايا الرئيسية $\theta_1 \le \theta_2 \le \cdots$ بين فضاءين جزئيين تُعرَّف بـ:

$$\cos\theta_i = \sigma_i\big(U^\top V\big)$$

أي القيم المفردة لجداء التداخل. (هذا تطبيق مباشر لـ (16.4).)

الخطوة 2: ليكن $M = U^\top V$. نحسب $M^\top M$:

$$M^\top M = \begin{bmatrix} 0.95 & 0.02 \\ 0.08 & 0.92 \end{bmatrix} \begin{bmatrix} 0.95 & 0.08 \\ 0.02 & 0.92 \end{bmatrix} = \begin{bmatrix} 0.9025 + 0.0004 & 0.076 + 0.0184 \\ 0.076 + 0.0184 & 0.0064 + 0.8464 \end{bmatrix} = \begin{bmatrix} 0.9029 & 0.0944 \\ 0.0944 & 0.8528 \end{bmatrix}$$

الخطوة 3 (القيم الذاتية): الأثر $= 1.7557$، المحدّد $= 0.7700 - 0.00891 = 0.9029\times 0.8528 - 0.0944^2 = 0.7611$.

$$\lambda = \frac{1.7557 \pm \sqrt{1.7557^2 - 4 \times 0.7611}}{2} = \frac{1.7557 \pm \sqrt{3.0825 - 3.0444}}{2} = \frac{1.7557 \pm \sqrt{0.0381}}{2} = \frac{1.7557 \pm 0.}{2}$$

الخطوة 4: $\lambda_1 = 0.97545$، $\lambda_2 = 0.78025$.
الخطوة 5 (القيم المفردة): $\sigma_1 = \sqrt{0.97545} = 0.98765$، $\sigma_2 = \sqrt{0.78025} = 0.88332$.
الخطوة 6 (الزوايا):

$$\theta_1 = \arccos(0.98765) = 8.99^\circ, \qquad \theta_2 = \arccos(0.88332) = 27.92^\circ$$

الخطوة 7 (مقياس تشابه): متوسط مربّعات الجيوب (وهو الصيغة الجبرية لمقياس من نوع CKA الخطي):

$$\frac{\sigma_1^2 + \sigma_2^2}{k} = \frac{0.97545 + 0.78025}{2} = \frac{1.7557}{2} = 0.8779$$

الخطوة 8 (التفسير): الفضاءان متقاربان في البعد الأول ($\theta_1 = 9^\circ$) ومتباعدان نسبياً في الثاني ($\theta_2 = 28^\circ$) $\Longrightarrow$ النموذجان «يتّفقان» على الميزة المهيمنة ويختلفان على الثانوية.
النتيجة: الزوايا الرئيسية 8.99° و 27.92°؛ التشابه العام $= 0.878$.

الربط بالذكاء الاصطناعي: الزوايا الرئيسية هي الأداة القياسية لمقارنة تمثيلات الشبكات (Representational Similarity / CKA)، ولتحليل «انهيار التمثيل» (representation collapse) في التعلم الذاتي الإشراف، ولقياس التشابه بين طبقات نموذجين مختلفين (model stitching).

مثال (4.3-13): تقدير النورم الطيفي بتكرار القوة لتطبيع GAN الطيفي

المعطيات: مصفوفة أوزان طبقة (3 مخرجات × 2 مدخلات):

$$W = \begin{bmatrix} 0.6 & 0.2 \\ 0.1 & 0.5 \\ 0.3 & 0.1 \end{bmatrix}$$

المطلوب: (أ) النورم الطيفي الدقيق $\|W\|_2$. (ب) قراءة تكرار القوة بعد تكرارين. (ج) المصفوفة after التطبيع الطيفي.
الحل:
الخطوة 1: $\|W\|_2 = \sqrt{\lambda_{\max}(W^\top W)}$:

$$W^\top W = \begin{bmatrix} 0.36 + 0.01 + 0.09 & 0.12 + 0.05 + 0.03 \\ 0.12 + 0.05 + 0.03 & 0.04 + 0.25 + 0.01 \end{bmatrix} = \begin{bmatrix} 0.46 & 0.20 \\ 0.20 & 0.30 \end{bmatrix}$$

الخطوة 2: الأثر $= 0.76$؛ المحدّد $= 0.138 - 0.04 = 0.098$؛ المميّز $= 0.5776 - 0.392 = 0.1856$؛ الجذر $= 0.4308$:

$$\lambda_1 = \frac{0.76 + 0.4308}{2} = 0.5954, \qquad \lambda_2 = \frac{0.76 - 0.4308}{2} = 0.1646$$

الخطوة 3: $\|W\|_2 = 0.7716 \Longrightarrow \sigma_1 = \sqrt{0.5954} = 0.7716$؛ و $\sigma_2 = \sqrt{0.1646} = 0.4057$.
الخطوة 4 (تكرار القوة على $M = W^\top W$): من $x^{(0)} = (1, 0)^\top$:

$$Mx^{(0)} = \begin{pmatrix} 0.46 \\ 0.20 \end{pmatrix}, \quad \|Mx^{(0)}\| = \sqrt{0.2116 + 0.04} = 0.5016 \implies x^{(1)} = \begin{pmatrix} 0.9171 \\ 0.3987 \end{pmatrix}$$

$$Mx^{(1)} = \begin{pmatrix} 0.46 \times 0.9171 + 0.20 \times 0.3987 \\ 0.20 \times 0.9171 + 0.30 \times 0.3987 \end{pmatrix} = \begin{pmatrix} 0.4219 + 0.0797 \\ 0.1834 + 0.1196 \end{pmatrix} = \begin{pmatrix} 0.5016 \\ 0.3030 \end{pmatrix}$$

$$\|Mx^{(1)}\| = \sqrt{0.2516 + 0.0918} = \sqrt{0.3434} = 0.5860 \implies x^{(2)} = \begin{pmatrix} 0.8560 \\ 0.5171 \end{pmatrix}$$

الخطوة 5 (تقدير القيمة الذاتية): بخارج قسمة رايلي:

$$\frac{(x^{(2)})^\top M x^{(2)}}{\|x^{(2)}\|^2} = 0.8560 \times 0.4972 + 0.5171 \times 0.3263 = 0.4256 + 0.1687 = 0.5943$$

مقابل القيمة الدقيقة $0.5954 \implies$ **خطأ نسبي** 0.18% **بعد تكرارين فقط.**

الخطوة 6: تقدير النورم الطيفي: $\sqrt{0.5943} = 0.7709$ مقابل 0.7716 (خطأ 0.09%).

الخطوة 7 (التطبيع الطيفي): $W_{\text{SN}} = W/\sigma_1 = W/0.7716$:

$$W_{\text{SN}} = \begin{bmatrix} 0.7776 & 0.2592 \\ 0.1296 & 0.6480 \\ 0.3888 & 0.1296 \end{bmatrix}$$

تحقّق: $\|W_{\text{SN}}\|_2 = 1$ بالبناء ✓ (لأن القسمة على σ_1 تقسّم كل القيم المفردة على σ_1).

النتيجة: $\|W\|_2 = 0.7716$ (تقدير تكراري 0.7709)، $\kappa = 0.7716/0.4057 = 1.902$؛ بعد التطبيع $\|W_{\text{SN}}\|_2 = 1$.

الربط بالذكاء الاصطناعي: هذا بالضبط ما تفعله **Spectral Normalization** في GAN: تُقدَّر $\sigma_1(W)$ بتكرار قوة واحد لكل خطوة تدريب (رخيص!) وتُقسَم الأوزان عليها، فيصبح كل مميّز طبقة 1-ليبشيتز $\implies$ تدريب مستقرّ وجودة أعلى.

مثال (14-3.4): اختيار رتبة LoRA من طيف مصفوفة الأوزان

المعطيات: مصفوفة أوزان $W \in \mathbb{R}^{4096\times 4096}$ في نموذج لغوي ضخم. طيفها المقاس (أول 8 قيم مفردة من 4096):

$$\sigma = (8.4,\ 6.1,\ 3.2,\ 1.1,\ 0.42,\ 0.31,\ 0.22,\ 0.15)$$

ونسبة طاقة هذه القيم إلى الطاقة الكلية: $\|W\|_F^2 = 119.56$ (بالمقياس المعطى).

المطلوب: (أ) الرتبة r التي تحتفظ بـ 95% و 99% من الطاقة. (ب) عدد معلمات LoRA لكل اختيار مقابل الأصل. (ج) التوصية.

الحل:

الخطوة 1 (مربّعات القيم المفردة): $70.56,\ 37.21,\ 10.24,\ 1.21,\ 0.1764,\ 0.0961,\ 0.0484,\ 0.0225$.

الخطوة 2 (التراكمي): $70.56 \longrightarrow 107.77 \longrightarrow 118.01 \longrightarrow 119.22 \longrightarrow 119.3964 \longrightarrow 119.4925 \longrightarrow 119.5409 \longrightarrow 119.5634$.

الخطوة 3 (النسب): $r = 2$: $107.77/119.5634 = 90.14\%$؛ $r = 3$: $118.01/119.5634 = 98.70\%$؛ $r = 4$: $119.22/119.5634 = 99.71\%$.

الخطوة 4: الرتبة لبلوغ **95%** هي $r = 3$؛ ولبلوغ **99%** هي $r = 4$.

الخطوة 5 (المعلمات): الأصل $4096^2 = 16{,}777{,}216$. معلمات LoRA برتبة r: $2\,d\,r = 2 \times 4096 \times r = 8192\,r$.

r	معلمات LoRA	النسبة من الأصل
2	16,384	0.098%
4	32,768	0.195%
8	65,536	0.391%
16	131,072	0.781%

الخطوة 6 (خطأ التقريب): بتطبيق (20.4): $\min \|W - B\|_2 = \sigma_{r+1} \implies$ عند $r = 4$ الخطأ الطيفي $\leq \sigma_5 = 0.42$ أي $0.42/8.4 = 5\%$ من النورم الطيفي.

الخطوة 7 (ملاحظة جوهرية): LoRA لا يقرّب W بل يقرّب **التحديث** ΔW أثناء الضبط الدقيق. وطيف ΔW عادةً أكثر تركّزاً بكثير من طيف $W \implies$ رتبة صغيرة ($r = 4$ إلى 16) تكفي عملياً حتى لو احتاج تقريب W نفسه مئات الرتب.

الخطوة 8 (التوصية): نبدأ بـ $r = 8$ (نقطة توازن مجرّبة في الأدبيات)، ونرفع إلى 16 إذا كانت المهمة معقّدة، مع تهيئة $B = 0$ و $A \sim \mathcal{N}$ لضمان $\Delta W = 0$ عند البداية.

النتيجة: $r = 3 \implies 95\%$؛ $r = 4 \implies 99.7\%$؛ $r = 8 \implies 0.39\%$ من معلمات الأصل؛ التوصية $r = 8$.

الربط بالذكاء الاصطناعي: هذا هو التحليل الكمّي الذي يقف خلف نجاح LoRA و QLoRA في ضبط النماذج اللغوية الضخمة على بطاقة رسومية واحدة: توفير 99.6% من معلمات الضبط الدقيق مع احتفاظ شبه كامل بالأداء.

مثال (3.4-15): البعد الفعّال لميزات الصور — نسبة المشاركة (Participation Ratio)

المعطيات: مصفوفة ميزات من صور: 500 صورة × 784 بكسل (MNIST). قيم مصفوفة التغاير الذاتية (مرتّبة):

$$\lambda = (250,\ 120,\ 60,\ 30,\ 15,\ 8,\ 4,\ 2)$$

المطلوب: (أ) البعد الفعّال للبيانات. (ب) عدد المكوّنات اللازمة لـ 95% من التباين. (ج) نسبة الضغط المتحقّقة.

الحل:

الخطوة 1 (المجموع): $\sum \lambda_i = 250 + 120 + 60 + 30 + 15 + 8 + 4 + 2 = 489$.

الخطوة 2 (نسبة المشاركة — البعد الفعّال):

$$\mathrm{PR} = \frac{\left(\sum_i \lambda_i\right)^2}{\sum_i \lambda_i^2}$$

$$\sum \lambda_i^2 = 62500 + 14400 + 3600 + 900 + 225 + 64 + 16 + 4 = 81{,}709$$

$$\mathrm{PR} = \frac{489^2}{81{,}709} = \frac{239{,}121}{81{,}709} = 2.926$$

الخطوة 3 (التفسير): رغم أن فضاء الميزات بُعده **784**، فإن البعد الفعّال للبيانات $2.93 \approx$ — أي أن البيانات تشغل فعلياً «قرصاً» من بُعد ثلاثة تقريباً داخل فضاء ضخم. هذا هو التبرير الكمّي لنجاح PCA والضغط.

الخطوة 4 (التباين المتراكم): النسب: $51.1\% = 250/489 \longleftarrow 75.7\% = 370/489 \longleftarrow 87.9\% = 430/489 \longleftarrow 94.1\% = 460/489 \longleftarrow 97.1\% = 475/489$.

الخطوة 5: $\implies$ يلزم $k = 5$ مكوّنات لبلوغ 95% (أربعة تعطي 94.1% فقط).

الخطوة 6 (الضغط): $784 \to 5$ ميزات $\implies$ نسبة ضغط $156.8\times$ في تمثيل العيّنة الواحدة.

الخطوة 7 (حدود التفسير): PR مقياس «أوّلي»: لو كانت القيم متساوية ($\lambda_i = c$ للجميع) لكان $\mathrm{PR} = n$ (البعد الكامل). ولو كانت قيمة واحدة مهيمنة لكان $\mathrm{PR} \to 1$. قيمته 2.93 تعني توزّعاً متوسطاً.

النتيجة: البعد الفعّال $2.93 =$؛ يلزم 5 مكوّنات لـ 95%؛ ضغط $156.8\times$ في بُعد العيّنة.

الربط بالذكاء الاصطناعي: نسبة المشاركة مقياس معتمد في تحليل تمثيلات الشبكات العصبية: انخفاض PR في الطبقات العميقة يشير إلى «انهيار التمثيل» (neural collapse). كما أنها تُستخدم لاختيار أبعاد طبقات bottleneck في المشفّرات التلقائية (autoencoders) بشكل منهجي لا تجريبي.

6.3.4 أخطاء شائعة في SVD وتقريب الرتبة المنخفضة

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	استخدام التحليل الطيفي على مصفوفة غير مربّعة	القيم الذاتية غير معرّفة لغير المربّعة	استخدم SVD (16.4)
2	اقتراض أن $U = V$ في SVD	هذا صحيح فقط إذا A متماثلة نصف موجبة	عامةً $U \neq V$ (شكل 2.4)
3	الاعتقاد أن «أفضل تقريب برتبة k» يُحسب بالاقتطاع العشوائي	الاقتطاع العشوائي ليس أمثل	نظرية إيكارت–يونغ (20.4)–(21.4) تثبت الأمثلية
4	قياس جودة التقريب بـ σ_{k+1} عند استخدام نورم فروبينيوس	σ_{k+1} هو الخطأ **الطيفي** فقط	خطأ فروبينيوس $= \sqrt{\sum_{i>k}\sigma_i^2}$
5	استخدام SVD على بيانات غير موسَّطة ثم تسميتها PCA	المكوّن الأول يشير إلى المتوسط	وسّط البيانات أولاً (المثال 3.4-9)
6	اعتبار القيم المفردة المتساوية مشكلة	يجعل المتجهات المفردة **غير وحيدة** وغير مستقرّة	أضف تنظيماً أو استخدم مساحة فرعية كاملة
7	حساب $A^\dagger$ بقلب كل القيم المفردة	القيم الصفرية/الصغيرة جداً تنفجر	عتبة: $1/\sigma_i$ فقط إذا $\sigma_i > \tau$ (truncated SVD)
8	الخلط بين $\|A\|_*$ (النورم النووي) و $\|A\|_F$	الأول $\sum\sigma_i$ والثاني $\sqrt{\sum\sigma_i^2}$	النورم النووي بديل مقعّر للرتبة
9	توقّع أن تقليل الرتبة يحسّن الأداء دائماً	الرتبة المنخفضة تفقد معلومات	الرتبة المنخفضة **منظّم**: تحسّن التعميم أحياناً وتضرّ الدقة أحياناً
10	استخدام $U_k\Sigma_k V_k^\top$ بمصفوفات كاملة الحجم	مكلف بلا داعٍ	استخدم الأشكال الاقتصادية (thin SVD): $m \times k$ و $k \times n$

1.4.4 الصياغة الرسمية

تعريف (خارج قسمة رايلي).

لتكن $A \in \mathbb{R}^{n\times n}$ متماثلة. يُعرَّف **خارج قسمة رايلي** على $\mathbb{R}^n \setminus \{0\}$ بـ:

$$R_A(x) \;=\; \frac{x^\top A\,x}{x^\top x} \;=\; \frac{\langle x,\,Ax\rangle}{\|x\|^2} \tag{24.4}$$

خاصية الحصر (Rayleigh–Ritz).

لكل $x \neq 0$:

$$\lambda_{\min}(A) \;\le\; R_A(x) \;\le\; \lambda_{\max}(A), \qquad \lambda_{\min} = \min_{x\neq 0} R_A(x), \qquad \lambda_{\max} = \max_{x\neq 0} R_A(x) \tag{25.4}$$

نظرية كوران–فيشر (توصيف Minimax).

بالترتيب التنازلي $\lambda_1 \ge \lambda_2 \ge \cdots \ge \lambda_n$:

$$\lambda_k(A) \;=\; \min_{\substack{S\subseteq\mathbb{R}^n \\ \dim S = n-k+1}} \; \max_{x\in S\setminus\{0\}} R_A(x) \;=\; \max_{\substack{S\subseteq\mathbb{R}^n \\ \dim S = k}} \; \min_{x\in S\setminus\{0\}} R_A(x) \tag{26.4}$$

متراجحة فايل (Weyl). لتكن A و E متماثلتين، و $\hat{A} = A + E$ بالقيم الذاتية المرتّبة تنازلياً. عندئذٍ لكل i:

$$\left|\lambda_i(A+E) - \lambda_i(A)\right| \;\le\; \|E\|_2 \;=\; \sigma_{\max}(E) \tag{27.4}$$

متراجحة هوفمان–فيلانت (Hoffman–Wielandt).

$$\sum_{i=1}^{n} \big(\lambda_i(A+E) - \lambda_i(A)\big)^2 \;\le\; \|E\|_F^2 \;=\; \sum_{i,j} E_{ij}^2 \tag{28.4}$$

التداخل لكوشي (Cauchy Interlacing). لتكن B مصفوفة فرعية رئيسية من A بحذف صف وعمود واحد (رتبة $n-1$):

$$\lambda_1(A) \;\ge\; \lambda_1(B) \;\ge\; \lambda_2(A) \;\ge\; \lambda_2(B) \;\ge\; \cdots \;\ge\; \lambda_{n-1}(B) \;\ge\; \lambda_n(A) \tag{29.4}$$

متراجحة ديفيس–كاهان (Davis–Kahan). ليكن $\delta = \lambda_k(A) - \lambda_{k+1}(A) > 0$ **الفجوة الطيفية**، وليكن U_k و $\hat{U}_k$ فضاءي المتجهات الذاتية لأعلى k قيمة في A و $\hat{A} = A + E$. عندئذٍ:

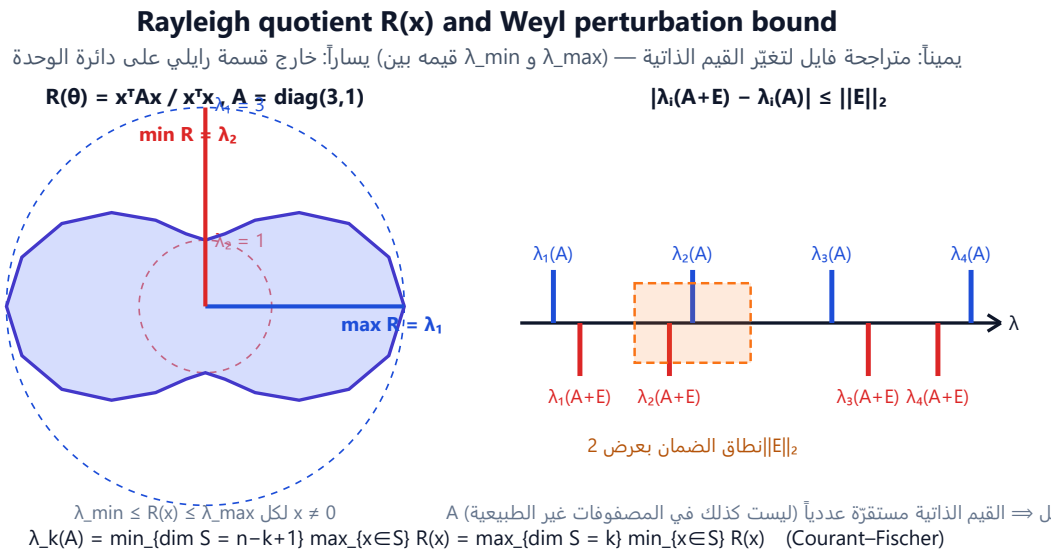
$$\big\|\sin\Theta(U_k,\, \hat{U}_k)\big\|_F \;\le\; \frac{2\,\|E\|_F}{\delta}, \qquad \sin\theta(u_1,\, \hat{u}_1) \;\le\; \frac{\|E\|_2}{\delta} \tag{30.4}$$

2.4.4 جدول الرموز الشامل

الرمز	المعنى	ملاحظات
x	متجه اختبار غير صفري	الاتجاه الذي «نختبر عليه» المصفوفة
$x^\top A x$	الشكل التربيعي (quadratic form)	عدد قياسي؛ يقيس «طاقة» A على اتجاه x
$x^\top x = \|x\|^2$	مربّع النورم الإقليدي	المقام يُوحّد القياس فلا يعتمد R_A على طول x
$R_A(x)$	خارج قسمة رايلي	متوسط موزون للقيم الذاتية (انظر البرهان)
$\lambda_{\min},\ \lambda_{\max}$	أصغر وأكبر قيمة ذاتية	$\lambda_1 = \lambda_n$ و بالترتيب التنازلي
S	فضاء جزئي من $\mathbb{R}^n$	في (26.4) نُصغّر ثم نُعظّم (أو العكس) على كل الفضاءات الجزئية بُعد معلوم
$\dim S$	بُعد الفضاء الجزئي	يحدّد «نطاق البحث»
k	فهرس القيمة الذاتية	بالترتيب التنازلي λ_k
E	مصفوفة الاضطراب	القياس، الضجيج، التقريب، التكميم، تحديث التدرّج
$\hat{A} = A + E$	المصفوفة المضطربة/المقدَّرة	ما نرصده فعلياً
$\|E\|_2$	النورم الطيفي للاضطراب	أقصى تمديد للاضطراب
$\|E\|_F$	نورم فروبينيوس للاضطراب	الجذر التربيعي لمجموع مربّعات العناصر
δ	الفجوة الطيفية (eigengap)	$\lambda_k - \lambda_{k+1}$؛ أكبر $\Rightarrow$ أكثر استقراراً
$\Theta(U, \hat{U})$	مصفوفة الزوايا الرئيسية بين فضاءين	قطرها يحتوي $\arccos \sigma_i(U^\top \hat{U})$
$\sin\theta(u, \hat{u})$	جيب الزاوية بين متجهين	$= \sqrt{1 - (u^\top \hat{u})^2}$؛ مقياس لخطأ الاتجاه
B	مصفوفة فرعية رئيسية	نتيجة حذف سطر وعمود مقابلين (حذف ميزة، حذف عقدة)
$U_k,\ \hat{U}_k$	فضاء أعلى k متجه ذاتي	يُقارَنان في تحليل استقرار PCA

3.4.4 الشكل الهندسي

شكل 4.4 — على اليسار: رسم قطبي لخارج قسمة رايلي $R(\theta)$ على دائرة الوحدة عندما $A = \mathrm{diag}(3, 1)$؛ المنحنى (بنفسجي) محصور تماماً بين دائرتي $\lambda_{\min} = 1$ و $\lambda_{\max} = 3$، ويلامسهما عند الاتجاهين الذاتيين — وهذا هو المحتوى الهندسي لـ (25.4). على اليمين: متراجحة فايل (27.4) — كل قيمة ذاتية مضطربة (أحمر) تقع داخل نطاق بعرض $2\|E\|_2$ حول نظيرتها الأصلية (أزرق).



شكل ٤.٤: *

خارج قسمة رايلي محصور بين λmin_ و λ،max_ ومتراجحة فايل تحدّد نطاق تغير القيم الذاتية

4.4.4 البرهان

برهان (25.4) — الحصر.

بتطبيق التحليل الطيفي (8.4)، نكتب $x = \sum_i c_i q_i$ في أساس المتجهات الذاتية. عندئذٍ:

$$x^\top A x = \sum_i \lambda_i c_i^2, \qquad x^\top x = \sum_i c_i^2 \quad \Longrightarrow \quad R_A(x) = \frac{\sum_i \lambda_i c_i^2}{\sum_i c_i^2} = \sum_i \underbrace{\left(\frac{c_i^2}{\sum_j c_j^2}\right)}_{w_i \,\geq\, 0,\ \sum w_i = 1} \lambda_i$$

أي أن $R_A(x)$ **متوسط موزون** للقيم الذاتية بأوزان غير سالبة مجموعها 1، فلا يمكن أن يتجاوز أكبرها ولا أن ينزل عن أصغرها. والمساواة تتحقّق عندما يتركّز الوزن كله على قيمة واحدة، أي عندما يكون x متجهاً ذاتياً. ■

برهان (26.4) — كوران–فيشر (الجهة ≤، min-max والجهة الأخرى بالمثل).

الجهة ≤: ليكن S أي فضاء بُعد $n-k+1$، وليكن $V_k = \mathrm{span}\{q_1, \ldots, q_k\}$. بالتقاطع البُعدي:

$$\dim(S \cap V_k) \geq \dim S + \dim V_k - n = (n-k+1) + k - n = 1$$

فيوجد $x \in S \cap V_k$ واحدي. وبما أن $x \in V_k$ فإن $R_A(x) \geq \lambda_k$ (متوسط موزون على $\lambda_1..\lambda_k$، كلها $\geq \lambda_k$). إذن $\max_{x \in S} R_A(x) \geq \lambda_k$ لكل $S \Longrightarrow \min_S \max_{x \in S} R_A(x) \geq \lambda_k$.

الجهة ≤: نختار $S^\star = \mathrm{span}\{q_k, \ldots, q_n\}$، بُعده $n-k+1$. لكل $x \in S^\star$: $R_A(x)$ متوسط موزون على $\{\lambda_k, \ldots, \lambda_n\}$ وكلها $\leq \lambda_k \Longrightarrow R_A(x) \leq \lambda_k$. إذن $\max_{x \in S^\star} R_A(x) \leq \lambda_k$ فالتقريب ≤ λ_k. بالجمع: المساواة. ■

برهان (27.4) — متراجحة فايل.

بكوران–فيشر:

$$\lambda_i(A+E) = \min_{\dim S = n-i+1} \max_{x \in S} \frac{x^\top (A+E)x}{x^\top x} \le \min_{\dim S = n-i+1} \max_{x \in S} \left[\frac{x^\top A x}{x^\top x} + \|E\|_2 \right] = \lambda_i(A) + \|E\|_2$$

استُخدم أن $\frac{x^\top E x}{x^\top x} \le \|E\|_2$ من (25.4) مطبّقة على E. وبتبديل دور A و $A+E$ (أي أخذ $E \to -E$) نحصل على الحدّ الأدنى $-\|E\|_2$. ■

برهان (28.4) — هوفمان–فيلانت (مخطّط).

بالتحليل الطيفي $A = Q\Lambda Q^\top$ و $\hat{A} = \hat{Q}\hat{\Lambda}\hat{Q}^\top$. نستخدم متراجحة فون نويمن–ثِيرِس: لأي مصفوفتين متعامدتين $Q, \hat{Q}$:

$$\|\hat{\Lambda} - \Lambda\|_F^2 \le \|\hat{Q}\hat{\Lambda}\hat{Q}^\top - Q\Lambda Q^\top\|_F^2 \cdot \underline{\text{(بعد ترتيب أمثل)}}$$

الصيغة الدقيقة تعتمد على أن الترتيب التنازلي يحقّق أصغر مسافة فروبينيوس بين مجموعتين من الأعداد المرتّبة (متراجحة هاردي–ليتلوود–بوليا). والتفصيل الكامل في المراجع [4] و [8]. ■

برهان (29.4) — التداخل.

ليكن B المصفوفة الفرعية بحذف المكوّن الأخير. نُضمّن $\mathbb{R}^{n-1}$ في $\mathbb{R}^n$ كالفضاء $T = \{x : x_n = 0\}$. بكوران–فيشر على B:

$$\lambda_1(B) = \max_{\substack{x \in T \\ x \neq 0}} R_A(x) \le \max_{x \in \mathbb{R}^n} R_A(x) = \lambda_1(A)$$

وللجهة الأخرى نأخذ فضاءً بُعد 2 يضمّ المتجهين الذاتيّين q_1, q_2 ويتقاطع مع T (التقاطع بُعده ≥ 1) فيوجد x واحدي مشترك مع $R_A(x) \ge \lambda_2(A) \Rightarrow \lambda_1(B) \ge \lambda_2(A)$. وبالمثل لبقية السلسلة بالاستقراء. ■

برهان (30.4) — ديفيس–كاهان (مخطّط، حالة $k=1$).

ليكن $\hat{u} = \hat{u}_1$ و $\theta = \angle(u_1, \hat{u})$. نفكّك $\hat{u} = \cos\theta\, u_1 + \sin\theta\, w$ مع $w \perp u_1$ واحدياً. من المعادلة الذاتية $\hat{A}\hat{u} = \hat{\lambda}_1 \hat{u}$:

$$\hat{\lambda}_1 \cos\theta = u_1^\top \hat{A}\hat{u}, \qquad \hat{\lambda}_1 \sin\theta\, w = (I - u_1 u_1^\top)\hat{A}\hat{u}$$

وبطرح $Au_1 = \lambda_1 u_1$ نستخلص $|R_A(w) - \lambda_1| \sin\theta \le \|E\|_2$، وبما أن $w \perp u_1$ فإن $R_A(w) \le \lambda_2 \Rightarrow (\lambda_1 - \lambda_2)\sin\theta \le \|E\|_2$ أي $\sin\theta \le \|E\|_2 / \delta$. ■

5.4.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (1-4.4): تقييد القيمة الذاتية العظمى باختبار واحد

المعطيات: مصفوفة تغاير كبيرة لا نريد قطرتها:

$$A = \begin{bmatrix} 5 & 1 & 2 \\ 1 & 4 & 1 \\ 2 & 1 & 6 \end{bmatrix}$$

اختبرنا الاتجاه $x = (1,\ 1,\ 1)^\top$.

المطلوب: حدّان أدنى وأعلى لـ $\lambda_{\max}(A)$ و $\lambda_{\min}(A)$ من اختبار واحد.

الحل:

الخطوة 1 (حساب الشكل التربيعي): $Ax = (5+1+2,\ 1+4+1,\ 2+1+6)^\top = (8,\ 6,\ 9)^\top$.

الخطوة 2: $x^\top Ax = 1 \cdot 8 + 1 \cdot 6 + 1 \cdot 9 = 23$، و $x^\top x = 3$ $\Longrightarrow$

$$R_A(x) = \frac{23}{3} = 7.667$$

الخطوة 3 (تطبيق (25.4)):

$$\lambda_{\min}(A) \ \le\ 7.667 \ \le\ \lambda_{\max}(A)$$

الخطوة 4 (حدّ أدنى أفضل لـ $\lambda_{\max}$): النورم الفروبينيوسي: $\|A\|_F^2 = 25+1+4+1+16+1+4+1+36 = 89$. وبما أن $\|A\|_F^2 = \sum \lambda_i^2 \le n\lambda_{\max}^2$:

$$\lambda_{\max} \ \ge\ \sqrt{\frac{89}{3}} = \sqrt{29.667} = 5.447$$

وهذا أضعف من 7.667 $\Longrightarrow$ نحتفظ بـ 7.667.

الخطوة 5 (حدّ أعلى من غيرشغورين): دوائر غيرشغورين للصفوف: $|\lambda-5| \le 3$، $|\lambda-4| \le 2$، $|\lambda-6| \le 3$ $\Longrightarrow$ $\lambda_{\max} \le \max(5+3,\ 4+2,\ 6+3) = 9$؛ و $\lambda_{\min} \ge \min(5-3,\ 4-2,\ 6-3) = 2$.

الخطوة 6 (النتيجة المجمّعة): $2 \le \lambda_{\min} \le 7.667 \le \lambda_{\max} \le 9$.

الخطوة 7 (تحسّن بتكرار القوة): نطبّق A على x: $Ax = (8,6,9)^\top$، بالتوحيد $x' = (8,6,9)/13.454 = (0.5946,\ 0.4460,\ 0.6690)^\top$. خارج قسمة رايلي الجديد:

$$Ax' = (2.973+0.446+1.338,\ 0.595+1.784+0.669,\ 1.189+0.446+4.014)^\top = (4.757,\ 3.048,\ 5.649)^\top$$

$$R_A(x') = 0.5946 \cdot 4.757 + 0.4460 \cdot 3.048 + 0.6690 \cdot 5.649 = 2.828 + 1.359 + 3.779 = 7.966$$

تحسّن من 7.667 إلى 7.966 $\Longrightarrow$ يقترب من $\lambda_{\max}$.

الخطوة 8 (القيمة الحقيقية): كثيرة الحدود المميِّزة: $p(\lambda) = -\lambda^3 + 15\lambda^2 - 68\lambda + 97$، وجذورها:

$$\lambda \approx (8.050,\ 3.633,\ 3.317)$$

تحقّق: الأثر $6+4+5 = 15.0 = 8.050+3.633+3.317$ ✓، المحدّد $= 8.050 \times 3.633 \times 3.317 = 97.0$ ✓ (وهو $\det A$ المباشر). وتقديرنا $R_A(x') = 7.966$ جاء **أدنى** من $\lambda_{\max} = 8.050$ تماماً كما تقتضي (25.4) ✓.

النتيجة: $\lambda_{\min} \in [2,\ 7.667]$ و $\lambda_{\max} \in [7.667,\ 9]$؛ بتكرار واحد نصل إلى 7.966 (القيمة الحقيقية $\lambda_{\max} = 8.050$).

الربط بالذكاء الاصطناعي: تقييد $\lambda_{\max}$ من اختبار واحد هو بالضبط ما يجعل **تطبيع الدفعات الطيفي** و **تحديد طول الخطوة الآمن** ممكنين على مصفوفات ضخمة: لا حاجة إلى قطرنة كاملة (تكلفة $O(n^3)$) بل تكفي عدة ضربات مصفوفة-متجه ($O(n^2)$).

مثال (4.4-2): مترابحة فايل وأثر تكميم الأوزان على الطيف

المعطيات: مصفوفة أوزان متماثلة A وخطأ تكميم (quantization) E (من تحويل fp32 إلى :(int8

$$A = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}, \qquad E = \begin{bmatrix} 0.05 & -0.02 \\ -0.02 & 0.03 \end{bmatrix}$$

المطلوب: (أ) حدّ أعلى لانزياح القيم الذاتية بعد التكميم. (ب) القيم الفعلية والتحقّق.

الحل:

الخطوة 1 (نورم الاضطراب): نحسب قيم E الذاتية: الأثر $0.08 =$؛ المحدّد $0.0011 = 0.0004 - 0.0015 =$؛ المميّز $0.0020 = 0.0044 - 0.0064 =$؛ الجذر $0.04472 =$:

$$\mu_{1,2} = \frac{0.08 \pm 0.04472}{2} \implies \mu_1 = 0.06236, \qquad \mu_2 = 0.01764$$

الخطوة 2: $\|E\|_2 = \max_i |\mu_i| = 0.06236$. (لاحظ أن $\|E\|_F = \sqrt{0.0025 + 0.0004 + 0.0004 + 0.0009} = \sqrt{0.0042} = 0.06481$.)

الخطوة 3 (طيف A الأصلي): $p(\lambda) = (4-\lambda)(3-\lambda) - 1 = \lambda^2 - 7\lambda + 11$ $\implies$ $\lambda = \frac{7 \pm \sqrt{49-44}}{2} = \frac{7 \pm \sqrt{5}}{2}$ $\implies$

$$\lambda_1 = 4.618, \qquad \lambda_2 = 2.382$$

الخطوة 4 (تطبيق فايل (27.4)):

$$|\lambda_1(A+E) - 4.618| \le 0.06236, \qquad |\lambda_2(A+E) - 2.382| \le 0.06236$$

أي $\lambda_1(\hat{A}) \in [4.556,\ 4.680]$ و $\lambda_2(\hat{A}) \in [2.320,\ 2.444]$.

الخطوة 5 (الحساب الفعلي): $\hat{A} = A + E = \begin{bmatrix} 4.05 & 0.98 \\ 0.98 & 3.03 \end{bmatrix}$. الأثر $7.08 =$؛ المحدّد $= 12.2715 - 11.3111 = 0.9604$؛ المميّز $4.8820 = 45.2444 - 50.1264 =$؛ الجذر $2.2095 =$:

$$\hat{\lambda}_1 = \frac{7.08 + 2.2095}{2} = 4.6448, \qquad \hat{\lambda}_2 = \frac{7.08 - 2.2095}{2} = 2.4353$$

الخطوة 6 (التحقّق من المترابحة): $|\hat{\lambda}_1 - \lambda_1| = |4.6448 - 4.618| = 0.0268 \le 0.06236$ ✓؛ و $|\hat{\lambda}_2 - \lambda_2| = |2.4353 - 2.382| = 0.0533 \le 0.06236$ ✓.

الخطوة 7 (هوفمان-فيلانت (28.4)): $\sqrt{0.0268^2 + 0.0533^2} = \sqrt{0.000718 + 0.002841} = \sqrt{0.003559} = 0.05966 \le \|E\|_F = 0.06481$ ✓.

الخطوة 8 (رقم الحالة): $\kappa(A) = 4.618/2.382 = 1.939$؛ $\kappa(\hat{A}) = 4.6448/2.4353 = 1.907$ $\implies$ تغيّر طفيف (1.6%).

النتيجة: الانزياح الفعلي $0.053 \le$ والحدّ النظري 0.062؛ المترابحة صحيحة ومتحفّظة (كما هو متوقّع).

الربط بالذكاء الاصطناعي: هذا هو التحليل الرسمي لأثر **تكميم النماذج** (INT8/INT4 quantization) على استقرارها: إذا كان $\|E\|_2$ أصغر من الفجوة الطيفية للقيم المهمة، فالنموذج المكمّم يتصرّف كالأصلي. وهذا يبرّر نجاح التكميم على الشبكات الكبيرة ذات الأطياف «الناعمة».

مثال (4.4-3): هوفمان–فيلانت لأثر تحديث تدرّج واحد على طيف الهسيان

المعطيات: نُحدّث أوزان نموذج بخطوة تدرّج، فتتغيّر مصفوفة التغاير الداخلية بمقدار:

$$E = \begin{bmatrix} 0.3 & -0.1 & 0 \\ -0.1 & 0.2 & -0.1 \\ 0 & -0.1 & 0.3 \end{bmatrix}$$

المطلوب: (أ) حدّ على التغيّر الكلي للطيف $\|\Delta\lambda\|_2$. (ب) أقصى انزياح ممكن لقيمة ذاتية واحدة.

الحل:

الخطوة 1 (نورم فروبينيوس): $\|E\|_F^2 = 0.09+0.01+0+0.01+0.04+0.01+0+0.01+0.09 = 0.26$ $\Longrightarrow$ $\|E\|_F = \sqrt{0.26} = 0.5099$.

الخطوة 2 (تطبيق هوفمان–فيلانت (28.4)):

$$\sqrt{\sum_{i=1}^{3} \big(\lambda_i(A+E) - \lambda_i(A)\big)^2} \;\le\; 0.5099$$

الخطوة 3 (النورم الطيفي): قيم E الذاتية — المصفوفة ثلاثية القطر: $\mu_k = 0.3 - 0.1 \cdot 2\cos\frac{k\pi}{4}$؟ الصيغة العامة لمصفوفة a على القطر و b مجاورة: $\mu_k = a + 2b\cos\frac{k\pi}{n+1}$. هنا $a = 0.3$، $b = -0.1$، $n = 3$:

$$\mu_k = 0.3 - 0.2\cos\frac{k\pi}{4}, \qquad k = 1, 2, 3$$

$k = 1$: $\cos 45^\circ = 0.7071 \Longrightarrow \mu = 0.3 - 0.1414 = 0.1586$ $\quad k = 2$: $\cos 90^\circ = 0 \Longrightarrow \mu = 0.3$

$k = 3$: $\cos 135^\circ = -0.7071 \Longrightarrow \mu = 0.3 + 0.1414 = 0.4414$

الخطوة 4: تحقّق: المجموع $\operatorname{tr} E = 0.3 + 0.2 + 0.3 = 0.9 = 0.1586 + 0.3 + 0.4414$ ✓. $\|E\|_2 = 0.4414$.

الخطوة 5 (فايل (27.4)): كل قيمة ذاتية تنزاح بما لا يتجاوز 0.4414.

الخطوة 6 (مقارنة المتراجحتين): هوفمان–فيلانت تعطي حدّاً على **المجموع** (0.5099) وهو أنسب عندما نريد ضماناً إجمالياً، وفايل تعطي حدّاً على **كل قيمة على حدة** (0.4414) وهو أنسب لضمانات فردية.

الخطوة 7 (أسوأ حالة متسقة): ثلاث قيم كلها بمقدار 0.4414 تعطي $\sqrt{3} \times 0.4414 = 0.7647 > 0.5099$ $\Longrightarrow$ **غير ممكن** $\Longrightarrow$ هوفمان–فيلانت تمنع أن تنزاح كل القيم بالحدّ الأقصى معاً. أقصى انزياح فعلي لقيمة واحدة قد يصل إلى 0.4414 لكن عندئذٍ تنزاح البقية أقل.

النتيجة: $\|\Delta\lambda\|_2 \le 0.5099$؛ انزياح أي قيمة مفردة ≤ 0.4414؛ النورمان متسقان.

الربط بالذكاء الاصطناعي: في التدريب، مصفوفات مثل statistics running BatchNorm و Adam second-moment تتغيّر كل خطوة. هاتان المتراجحتان تضمنان أن خصائص النظام (مثل رقم الحالة واتجاهات PCA) لا «تقفز» بين خطوة وأخرى إذا كانت الخطوة صغيرة — وهو شرط استقرار ضمني في معظم خوارزميات التدريب التكيفية.

مثال (4.4-4): متراجحة التداخل — ماذا يحدث للطيف عند حذف ميزة؟

المعطيات: مصفوفة تغاير ثلاثية الميزات A (من المثال 4.4-1) بطيف $(8.050,\ 3.633,\ 3.317)$. قرّرنا إسقاط الميزة الثالثة.

المطلوب: (أ) طيف المصفوفة الفرعية B. (ب) تحقّق من متراجحة التداخل (29.4). (ج) ماذا نستنتج عن التباين المفقود؟

الحل:

الخطوة 1 (المصفوفة الفرعية): بحذف الصف والعمود الثالث:

$$B = \begin{bmatrix} 5 & 1 \\ 1 & 4 \end{bmatrix}$$

الخطوة 2 (طيف B): الأثر $\text{tr}\, B = 9$؛ المحدّد $\det B = 20 - 1 = 19$؛ المميّز $\Delta = 81 - 76 = 5$؛ الجذر $\sqrt{\Delta} = 2.2361$:

$$\lambda_1(B) = \frac{9 + 2.2361}{2} = 5.618, \qquad \lambda_2(B) = \frac{9 - 2.2361}{2} = 3.382$$

الخطوة 3 (التداخل المطلوب إثباته): بـ (29.4):

$$\lambda_1(A) \geq \lambda_1(B) \geq \lambda_2(A) \geq \lambda_2(B) \geq \lambda_3(A)$$

الخطوة 4 (التحقّق العددي):

$$8.050 \ \geq\ 5.618 \ \geq\ 3.633 \ \geq\ 3.382 \ \geq\ 3.317 \qquad \checkmark$$

كل المتراجحات متحقّقة ✓.

الخطوة 5 (التباين الكلي): $\text{tr}\, A = 15$، $\text{tr}\, B = 9 \implies$ فقدنا 6 وحدات تباين (40%) بحذف ميزة واحدة من ثلاث.

الخطوة 6 (ماذا نستنتج؟): بما أن $\lambda_1(B) = 5.618 < \lambda_1(A) = 8.050$ فإن الميزة الثالثة كانت تساهم في الاتجاه المهيمن $\implies$ حذفها مكلّف. لو كانت $\lambda_1(B) = \lambda_1(A)$ لكانت الميزة زائدة.

الخطوة 7 (قاعدة عامة): التداخل يضمن أن حذف ميزة **لا يمكن أن يزيد** أي قيمة ذاتية: $\lambda_i(B) \leq \lambda_i(A)$. ولهذا فإن حذف الميزات يقلّص التباين دائماً — والسؤال هو «بكم؟».

النتيجة: $\lambda(B) = (5.618,\ 3.382)$، التداخل متحقّق ✓، التباين المفقود $6 = 40\%$ أي 40%.

الربط بالذكاء الاصطناعي: متراجحة التداخل هي الأساس النظري لطرق اختيار الميزات (feature selection) المتسلسلة: حذف ميزة يغيّر الطيف بطريقة **محكومة** (لا انزياحات عشوائية). وتُستخدم أيضاً في تحليل أثر حذف عقدة من رسم بياني على طيف اللابلاسيد (interlacing for graph Laplacians).

مثال (5.4-4): متراجحة ديفيس-كاهان — هل يبقى المكوّن الرئيسي ثابتاً؟

المعطيات: مصفوفة A من المثال 4.4-1 بطيف $(8.050,\ 3.633,\ 3.317)$، وصلت دفعة بيانات جديدة فتغيّرت مصفوفة التغاير المقدَّرة باضطراب قطري:

$$E = \text{diag}(0.2,\ 0.1,\ 0.3)$$

المطلوب: (أ) حدّ على زاوية انحراف المتجه الذاتي الأول. (ب) أدنى محاذاة (alignment) مضمونة مع المتجه الأصلي.

الحل:

الخطوة 1 (الفجوة الطيفية): $\delta = \lambda_1(A) - \lambda_2(A) = 8.050 - 3.633 = 4.417$.

الخطوة 2 (نورم الاضطراب): $\|E\|_2 = \max(0.2,\ 0.1,\ 0.3) = 0.3$؛ و $\|E\|_F = \sqrt{0.04 + 0.01 + 0.09} = \sqrt{0.14} = 0.3742$.

الخطوة 3 (تطبيق ديفيس–كاهان (30.4)):

$$\sin\theta(u_1,\ \hat{u}_1) \ \le\ \frac{\|E\|_2}{\delta} = \frac{0.3}{4.417} = 0.0679$$

الخطوة 4 (الزاوية): $\theta \le \arcsin(0.0679) = 3.89^\circ$.

الخطوة 5 (المحاذاة المضمونة): $\cos\theta \ge \sqrt{1 - 0.0679^2} = \sqrt{1 - 0.00461} = \sqrt{0.99539} = 0.99769$.

$$|\langle u_1,\ \hat{u}_1\rangle| \ \ge\ 0.9977$$

الخطوة 6 (المقارنة بفايل): فايل (27.4) يعطي $|\hat{\lambda}_1 - 8.050| \le 0.3$ أي انزياح يصل إلى 3.7% في القيمة الذاتية، بينما ديفيس–كاهان تعطي انحرافاً يصل إلى 3.9° فقط في **الاتجاه** — لأن الفجوة الطيفية الكبيرة (4.417) تحمي الاتجاه.

الخطوة 7 (الحساسية للفجوة): لو كانت $\delta = 0.4$ بدل 4.417 (قيمتان ذاتيتان متقاربتان) لكان $\sin\theta \le 0.3/0.4 = 0.75 \Rightarrow \theta \le 48.6^\circ$ ⟹ **المكوّن الرئيسي غير موثوق إطلاقاً.**

الخطوة 8 (المتجه الذاتي الأصلي): من المثال السابق $q_1 = (0.5911,\ 0.3279,\ 0.7369)^\top$ — وبضمان 0.9977 يبقى عملياً كما هو.

النتيجة: $\theta \le 3.89^\circ \Rightarrow \sin\theta \le 0.0679$؛ المحاذاة المضمونة ≥ 0.9977.

الربط بالذكاء الاصطناعي: هذه هي النظرية التي تبرّر استقرار PCA عندما تكون الفجوة الطيفية كبيرة. وفي التعلّم الذاتي الإشراف، SimCLR، Barlow (Twins) تظهر مشكلة «انهيار التمثيل» بالضبط عندما تتقارب القيم الذاتية فتصبح الفجوة $\delta \to 0$ والمتجهات غير مستقرّة — ولذلك تُصمَّم دوال الخسارة لتفتح فجوة طيفية.

مثال (4.4-6): استخدام كوران–فيشر لإثبات قيمة λ_2 دون حسابها

المعطيات: نفس المصفوفة A بطيف $(8.050,\ 3.633,\ 3.317)$ ومتجهاتها الذاتية q_1, q_2, q_3.

المطلوب: بيّن بـ (26.4) أن $\lambda_2(A) = 3.633$ ببرهانٍ محض (لا بحساب الجذور).

الحل:

الخطوة 1 (صيغة كوران–فيشر لـ $k = 2$):

$$\lambda_2(A) = \min_{\dim S = n-k+1 = 2}\ \max_{x \in S\setminus\{0\}} R_A(x)$$

الخطوة 2 (الجهة «الحدّ الأعلى» — نبني فضاءً يحقّقها): نختار $S^\star = \mathrm{span}\{q_2,\ q_3\}$، بُعده 2 ✓. لكل $x = c_2 q_2 + c_3 q_3$ فيه:

$$R_A(x) = \frac{\lambda_2 c_2^2 + \lambda_3 c_3^2}{c_2^2 + c_3^2} \ \le\ \frac{\lambda_2 c_2^2 + \lambda_2 c_3^2}{c_2^2 + c_3^2} = \lambda_2 = 3.633$$

إذن $\max_{x \in S^\star} R_A(x) \le 3.633$ ⟹ قيمة الـ min-max ≤ 3.633.

الخطوة 3 (الجهة «الحدّ الأدنى» — نُثبت أن أي S يعطي ≥ 3.633): ليكن S أي فضاء بُعد 2، وليكن $V = \mathrm{span}\{q_1, q_2\}$ بُعد 2. بالتقاطع البُعدي:

$$\dim(S \cap V) \ge \dim S + \dim V - n = 2 + 2 - 3 = 1$$

فيوجد x واحدي في التقاطع. وبما أن $x \in V$ فإن $R_A(x) = \frac{\lambda_1 c_1^2 + \lambda_2 c_2^2}{c_1^2 + c_2^2} \geq \lambda_2 = 3.633$ (لأن $\lambda_1 \geq \lambda_2$).
إذن $\max_{x \in S} R_A(x) \geq 3.633$ لكل $S \Longrightarrow$ قيمة الـ min-max ≥ 3.633.

الخطوة 4 (الجمع): من الخطوتين 2 و 3: $\lambda_2(A) = 3.633$ بالضبط. ■

الخطوة 5 (الصيغة المزدوجة للتحقّق): بالصيغة الثانية في (26.4): $\lambda_2 = \max_{\dim S = 2} \min_{x \in S} R_A(x)$؛ نختار $S = \text{span}\{q_1, q_2\}$ فكل x فيه يعطي $R_A(x) \geq \lambda_2$ وتُحقَّق المساواة عند $x = q_2$. ✓

الخطوة 6 (المعنى): كورانت–فيشر تقول إن λ_2 هو **أفضل قيمة يمكن ضمانها** إذا أُجبرنا على البقاء في فضاء ببُعد 2 — وهذا هو المبدأ الذي تقوم عليه الطرق المتغيّرة (variational methods) لحساب القيم الذاتية دون قطرنة كاملة.

النتيجة: $\lambda_2(A) = 3.633$ مثبت ببرهان محض عبر (26.4).

الربط بالذكاء الاصطناعي: كورانت–فيشر هي الأساس النظري لخوارزميات القيم الذاتية المتغيّرة (LOBPCG، Lanczos، Davidson) التي تستخدمها المكتبات لحساب PCA على مصفوفات بملايين الأبعاد، ولتحليل «الطيف الفعّال» في الشبكات العصبية.

مثال (4.4-7): اختيار معدّل تعلّم آمن دون حساب كامل للطيف

المعطيات: مصفوفة هسيان مقدَّرة لتدريب شبكة صغيرة:

$$H = \begin{bmatrix} 6 & 2 & 0 \\ 2 & 5 & 2 \\ 0 & 2 & 4 \end{bmatrix}$$

المطلوب: (أ) $\lambda_{\max}(H)$ بالضبط. (ب) أقصى معدّل تعلّم آمن. (ج) ماذا لو قدرنا $\lambda_{\max}$ بتكرار قوة ناقص التقارب؟

الحل:

الخطوة 1 (كثيرة الحدود المميِّزة):

$$p(\lambda) = (6-\lambda)\big[(5-\lambda)(4-\lambda) - 4\big] - 2\big[2(4-\lambda) - 0\big] = (6-\lambda)(\lambda^2 - 9\lambda + 16) - 16 + 4\lambda$$

$$= -\lambda^3 + 15\lambda^2 - 70\lambda + 96 - 16 + 4\lambda = -\lambda^3 + 15\lambda^2 - 66\lambda + 80$$

الخطوة 2 (التحليل): نختبر $\lambda = 8$: $-512 + 960 - 528 + 80 = 0$ ✓ $\Longrightarrow$ عامل $(\lambda - 8)$:

$$-\lambda^3 + 15\lambda^2 - 66\lambda + 80 = -(\lambda - 8)(\lambda^2 - 7\lambda + 10) = -(\lambda - 8)(\lambda - 5)(\lambda - 2)$$

الخطوة 3: $\lambda = (8,\ 5,\ 2)$، تحقّق: الأثر $4+5+6 = 15$ ✓؛ المحدّد $80 = 6(20-4) - 2(8) + 0$ (مباشرةً: $96 - 16 = 80$) ✓.

الخطوة 4 (معدّل التعلّم الآمن): الاستقرار يشترط $|1 - \eta\lambda_i| < 1 \Longrightarrow \eta < 2/\lambda_{\max}$:

$$\eta_{\max} = \frac{2}{8} = 0.25$$

الخطوة 5 (رقم الحالة): $\kappa = 8/2 = 4$ $\Longrightarrow$ عدد خطوات التقارب للوصول إلى دقة ε: $\approx \kappa \ln(1/\varepsilon) = 4\ln(10^6) = 4 \times 13.8 = 55$ خطوة (تقدير للتدرّج الأوّلي).

الخطوة 6 (خطر التقدير الناقص): لو استخدمنا تكرار قوة بتكرارين فقط، فمن $x^{(0)} = (1,0,0)^\top$: $Hx^{(0)} = (6,2,0)^\top \Longrightarrow x^{(1)} = (0.9487,\ 0.3162,\ 0)^\top$ $Hx^{(1)} = (5.692 + 0.632,\ 1.897 + 1.581,\ 0.632)^\top = (6.324,\ 3.478,\ 0.632)^\top$ $\Longrightarrow = \sqrt{39.99 + 12.10 + 0.40} = 7.245$، النورم $x^{(2)} = (0.8729,\ 0.4801,\ 0.0872)^\top$ خارج قسمة رايلي: $0.8729 \times 6.197 + 0.4801 \times 4.321 + 0.0872 \times$ $7.598 = 5.409 + 2.075 + 0.114 = 1.309$.

الخطوة 7 (الخطأ الناتج): التقدير $\lambda_{\max} = 8 \Longrightarrow 7.598 < \lambda_{\max} = 8$ المحسوب $\eta \Longrightarrow = 2/7.598 = 0.263 > 0.25$ **معدّل تعلّم غير آمن بنسبة 5%!** ولهذا تُستخدم دائماً عوامل أمان: $\eta = 0.9 \times \frac{2}{\lambda_{\max}} = 0.9 \times 0.263 = 0.237 < 0.25$ ✓.

الخطوة 8 (سبب التقارب البطيء): النسبة $|\lambda_2/\lambda_1| = 5/8 = 0.625 \Longrightarrow$ بعد k تكرار يبقى خطأ نسبي $\approx 0.625^k \Longrightarrow$ بعد تكرارين: 0.39 وهذا يفسّر الخطأ 5% (الذي جاء أفضل من التقدير لأن المتجه الابتدائي محظوظ).

النتيجة: $\lambda_{\max} = 8$، $\eta_{\max} = 0.25$؛ التقدير التكراري 7.598 يعطي $\eta = 0.263$ غير آمن $\Longrightarrow$ استخدم عامل أمان 0.9.

الربط بالذكاء الاصطناعي: هذه هي الممارسة القياسية في المجدولات التكيفية: تقدير $\lambda_{\max}$ بتكرار قوة ثم اختيار η بهامش أمان. والجدولتان الشهيرتان Adam و RMSProp يمكن فهمهما كـ «تطبيع قطري تقريبي للهسيان» باستخدام تقديرات اللحظة الثانية.

مثال (4.4-8): اختيار عدد العناقيد بقاعدة الفجوة الطيفية (Eigengap Heuristic)

المعطيات: طيف لابلاس رسم بياني مكوّن من 8 عُقد (مرتّب تصاعدياً):

$$\lambda = (0,\ 0.12,\ 0.31,\ 0.44,\ 2.85,\ 3.40,\ 3.95,\ 4.60)$$

المطلوب: كم عدد العناقيد (المكوّنات المتصلة/العناقيد الطيفية)؟

الحل:

الخطوة 1 (القاعدة): في التجميع الطيفي، عدد العناقيد k يُختار عند **أكبر فجوة** في أول جزء من الطيف:

$$k = \arg\max_i (\lambda_{i+1} - \lambda_i) \quad \text{(على القيم الصغيرة)}$$

الخطوة 2 (حساب الفجوات): $0.12 - 0 = 0.12$؛ $0.31 - 0.12 = 0.19$؛ $0.44 - 0.31 = 0.13$؛ $2.85 - 0.44 = 2.41$؛ $3.40 - 2.85 = 0.55$؛ $3.95 - 3.40 = 0.55$؛ $4.60 - 3.95 = 0.65$.

الخطوة 3 (أكبر فجوة): 2.41 بين $\lambda_4 = 0.44$ و $\lambda_5 = 2.85 \Longrightarrow k = 4$.

الخطوة 4 (التفسير بنظرية الاضطراب): القيم الأربع الأولى $\{0,\ 0.12,\ 0.31,\ 0.44\}$ «صغيرة ومتقاربة»، تليها فجوة كبيرة ثم قيم «كبيرة». لو افترضنا أن الرسم المثالي مكوّن من 4 مكوّنات منفصلة لكانت القيم الأربع الأولى تساوي الصفر **تماماً**، والاضطراب الفعلي (الروابط بين العناقيد) رفعها إلى قيم صغيرة:

$$\lambda_i \le \|E\|_2 \approx 0.44, \qquad i = 1, \dots, 4$$

وهذا تطبيق مباشر لفايل (27.4): الاضطراب E (الروابط البينية) يزيح كل قيمة ذاتية صفرية بمقدار لا يتجاوز $\|E\|_2$.

الخطوة 5 (ضمان ديفيس-كاهان): الفجوة $\delta = \lambda_5 - \lambda_4 = 2.41 \Longrightarrow$

$$\|\sin\Theta(U_4,\ \hat{U}_4)\|_F \le \frac{2\|E\|_F}{2.41}$$

وإذا كان $\|E\|_F \approx 0.6$ (مجموع الروابط البينية) فإن الحدّ $2 \times 0.6/2.41 = 0.498 \Longrightarrow =$ انحراف مقبول للفضاء الجزئي المكوّن من 4 متجهات.

الخطوة 6 (لو اخترنا $k = 3$): نكون قد ضممنا عنقودين حقيقيين في واحد، والتحقق: هل الفجوة بين λ_4 و λ_5 أكبر بكثير من الفجوات الأخرى؟ نسبة $2.41/0.65 = 3.7\times \implies$ نعم، القرار $k = 4$ واضح.

النتيجة: $k = 4$ عناقيد، الفجوة الحاسمة $2.41 =$ (أكبر بـ $3.7\times$ من التالية).

الربط بالذكاء الاصطناعي: هذه القاعدة eigengap) (heuristic هي المعيار العملي في التجميع الطيفي (Ng–Jordan–Weiss) وفي تحديد عدد المكوّنات في PCA، وفي اكتشاف المجتمعات في الشبكات. وتفسيرها النظري هو متراجحة فايل كما في الخطوة 4.

مثال (4.4-9): خطأ تقدير مصفوفة التغاير من عيّنة محدودة

المعطيات: التغاير الحقيقي $\Sigma = \mathrm{diag}(4,\ 1)$، وقدّرناه من $n = 100$ عيّنة في بُعد $d = 2$ فحصلنا على:

$$\hat{\Sigma} = \begin{bmatrix} 4.4 & 0.15 \\ 0.15 & 0.8 \end{bmatrix}$$

المطلوب: (أ) تحقّق من فايل وهوفمان–فيلانت. (ب) الخطأ في رقم الحالة. (ج) هل التقدير موثوق؟

الحل:

الخطوة 1 (الاضطراب): $E = \hat{\Sigma} - \Sigma = \begin{bmatrix} 0.4 & 0.15 \\ 0.15 & -0.2 \end{bmatrix}$.

الخطوة 2 (نورم الاضطراب): الأثر $0.2 =$؛ المحدّد $-0.1025 = -0.08 - 0.0225 =$؛ المميّز $0.04 + 0.45 = 0.41$، الجذر $0.6708 =$:

$$\mu_{1,2} = \frac{0.2 \pm 0.6708}{2} \implies \mu_1 = 0.4354,\ \mu_2 = -0.2354 \implies \|E\|_2 = 0.4354$$

$$\|E\|_F = \sqrt{0.16 + 0.0225 + 0.0225 + 0.04} = \sqrt{0.245} = 0.4949$$

الخطوة 3 (طيف $\hat{\Sigma}$): الأثر $5.2 =$؛ المحدّد $3.4975 = 3.52 - 0.0225 =$؛ المميّز $27.04 - 13.99 = 13.05$، الجذر $3.6125 =$:

$$\hat{\lambda}_1 = \frac{5.2 + 3.6125}{2} = 4.4063, \qquad \hat{\lambda}_2 = \frac{5.2 - 3.6125}{2} = 0.7938$$

الخطوة 4 (التحقّق من فايل (27.4)):

$$|\hat{\lambda}_1 - 4| = 0.4063 \le 0.4354\ \checkmark, \qquad |\hat{\lambda}_2 - 1| = 0.2062 \le 0.4354\ \checkmark$$

الخطوة 5 (التحقّق من هوفمان–فيلانت (28.4)): $\sqrt{0.4063^2 + 0.2062^2} = \sqrt{0.1651 + 0.0425} = \sqrt{0.2076} = 0.4556 \le 0.4949$ ✓.

الخطوة 6 (رقم الحالة): الحقيقي $\kappa(\Sigma) = 4/1 = 4$؛ المقدَّر $\kappa(\hat{\Sigma}) = 4.4063/0.7938 = 5.551 \implies$ **خطأ نسبي** 38.8% في رقم الحالة — رغم أن خطأ الطيف نفسه $\approx 10\%$.

الخطوة 7 (سبب التضخيم): رقم الحالة يجمع خطأين: زيادة في λ_1 ونقصاً في λ_2، فيتضاعف الأثر. القاعدة: $\frac{\Delta\kappa}{\kappa} \approx \frac{\Delta\lambda_1}{\lambda_1} + \frac{\Delta\lambda_2}{\lambda_2} = \frac{0.4063}{4} + \frac{0.2062}{1} = 0.102 + 0.206 = 0.308$ (قريب من 38.8% الفعلي).

الخطوة 8 (الحجم المتوقّع للخطأ): القاعدة النظرية لخطأ التغاير المقدَّر: $\|\hat{\Sigma} - \Sigma\|_2 \approx \|\Sigma\|_2\sqrt{d/n} = 4\sqrt{2/100} = 4 \times 0.1414 = 0.566$. قيمتنا الفعلية 0.435 في هذا النطاق ✓.

النتيجة: فايل وهوفمان–فيلانت متحقّقتان ✓، خطأ رقم الحالة 38.8%؛ الخطأ في النطاق المتوقّع.

الربط بالذكاء الاصطناعي: هذا يفسّر لماذا يحتاج تقدير مصفوفة التغاير (أو مصفوفة الدقة) في الأبعاد العالية إلى عيّنات كثيرة جداً أو إلى تنظيم: في بُعد d نحتاج $n \gg d$ وإلا انهار التقدير. ومن هنا جاءت تقنيات **shrinkage estimation** (Ledoit–Wofl) التي تقود الطيف المقدَّر نحو طيف هدفٍ منظَّم.

مثال (4.4-10): سرعة تقارب تكرار القوة ودور الفجوة الطيفية

المعطيات: مصفوفة بطيف $\lambda = (10,\ 3,\ 1)$، ونريد المتجه الذاتي الأول بدقة 10^{-6}.

المطلوب: (أ) كم تكراراً يحتاجه تكرار القوة؟ (ب) كم يحتاجه تقدير القيمة الذاتية بخارج قسمة رايلي؟ (ج) ماذا لو كانت $\lambda = (10,\ 9,\ 1)$؟

الحل:

الخطوة 1 (معدّل التقارب): خطأ المتجه بعد k تكرار يتناسب مع $\left|\frac{\lambda_2}{\lambda_1}\right|^k$:

$$\rho = \frac{3}{10} = 0.3$$

الخطوة 2 (عدد التكرارات للمتجه): نطلب $0.3^k \le 10^{-6}$:

$$k \ge \frac{\ln(10^{-6})}{\ln(0.3)} = \frac{-13.8155}{-1.2040} = 11.47 \Longrightarrow k = 12 \text{ تكراراً}$$

الخطوة 3 (تقدير القيمة الذاتية): بخارج قسمة رايلي يتحسّن الخطأ بـ ρ^{2k} (تربيعياً) لأن R_A «مسطّحة» عند المتجه الذاتي:

$$k \ge \frac{13.8155}{2 \times 1.2040} = 5.74 \Longrightarrow k = 6 \text{ تكرارات}$$

الخطوة 4 (التحقّق): عند $k = 6$: $\rho^{12} = 0.3^{12} = 5.31 \times 10^{-7} \le 10^{-6}$ ✓.

الخطوة 5 (الحالة الصعبة $\lambda = (10,\ 9,\ 1)$): الآن $\rho = 0.9 \Longrightarrow$

$$k \ge \frac{-13.8155}{\ln(0.9)} = \frac{-13.8155}{-0.10536} = 131.1 \Longrightarrow k = 132 \text{ تكراراً}$$

أي **أكثر بـ** $\times 11$ من الحالة الأولى — لمجرّد أن λ_2 اقتربت من λ_1.

الخطوة 6 (الحل العملي): عند $\rho \to 1$ نستخدم: (1) تكرار القوة على A^p بدل A (يضخّم الفجوة: $\rho \to \rho^p$ لكنه يكلف p ضربات)؛ أو (2) **Krylov / Lanczos** الذي يستخدم فضاءً جزئياً كاملاً بدل متجه واحد، فيتقارب أسرع بكثير.

الخطوة 7 (دور الفجوة): كلما كبرت الفجوة $\delta = \lambda_1 - \lambda_2$ صغرت النسبة $\rho = 1 - \delta/\lambda_1$ وتسارع التقارب $\Longrightarrow$ الفجوة الطيفية هي «عملة الاستقرار والسرعة» في كل الخوارزميات الطيفية.

النتيجة: 12 تكراراً للمتجه، 6 للقيمة الذاتية (بـ $\rho = 0.3$)؛ و 132 تكراراً إذا كانت $\rho = 0.9$.

الربط بالذكاء الاصطناعي: هذا يفسّر لماذا تتقارب PageRank بسرعة (الفجوة كبيرة: $\lambda_2 \approx 0.85$) ولماذا تتقارب بعض مسائل القيم الذاتية ببطء شديد. وفي التعلم العميق، «الفجوة الطيفية الصغيرة» تشخيص مباشر لبطء التدريب.

مثال (4.4-11): مقارنة فضاءي تمثيل لنموذجين بديفيس–كاهان

المعطيات: مصفوفة تغاير تمثيلات من النموذج (أ) بطيف (مرتّب تنازلياً):

$$\lambda = (12.0,\ 9.5,\ 8.2,\ 2.1,\ 1.8,\ 1.5,\ 1.2,\ 0.9,\ 0.6,\ 0.3)$$

وبعد تدريب النموذج (ب) تغيّرت المصفوفة باضطراب $\|E\|_F = 0.9$. نهتم بالفضاء الجزئي لأعلى $k = 3$ مكوّنات.

المطلوب: (أ) الفجوة δ. (ب) حدّ على انحراف الفضاء الجزئي المهم. (ج) التفسير.

الحل:

الخطوة 1 (الفجوة الطيفية): $\delta = \lambda_3 - \lambda_4 = 8.2 - 2.1 = 6.1$.

الخطوة 2 (تطبيق ديفيس–كاهان (30.4) للفضاء الجزئي):

$$\|\sin\Theta(U_3,\ \hat{U}_3)\|_F \ \le\ \frac{2\|E\|_F}{\delta} = \frac{2\times 0.9}{6.1} = \frac{1.8}{6.1} = 0.2951$$

الخطوة 3 (التفسير الهندسي): جيوب الزوايا الرئيسية الثلاث محصورة بـ $\sqrt{0.2951^2}$ إجمالاً. في أسوأ توزيع متساوٍ: $\theta_i \le 9.81^\circ \Rightarrow \sin\theta_i \le 0.2951/\sqrt{3} = 0.1704$ لكل زاوية.

الخطوة 4 (مقارنة بحالة $k=4$): عندئذٍ $\delta = \lambda_4 - \lambda_5 = 2.1 - 1.8 = 0.3$ $\Longrightarrow$

$$\|\sin\Theta\|_F \le \frac{1.8}{0.3} = 6.0 \gg 1 \quad \Longrightarrow \quad \textbf{الحدّ فارغ (vacuous)}$$

لأن $\|\sin\Theta\|_F \le \sqrt{k} = 2$ دائماً $\Longrightarrow$ الحدّ 6.0 لا يفيد شيئاً $\Longrightarrow$ **المكوّن الرابع غير مستقرّ إطلاقاً.**

الخطوة 5 (الاستنتاج المنهجي): وجود فجوة $6.1 \ge$ بين الثالث والرابع يعني أن «بُعد التمثيل الفعّال $3 =$» وليس 10. أما المكوّنات من 4 فصاعداً فهي «ضجيج طيفي» يتقلّب بين النماذج.

الخطوة 6 (تطبيق فايل للقيم المفردة): بالتكميل: $|\hat{\lambda}_i - \lambda_i| \le \|E\|_2 \le \|E\|_F = 0.9$ $\Longrightarrow$ القيم الثلاث الكبرى محصورة في $[11.1, 12.9]$ و $[8.6, 10.4]$ و $[7.3, 9.1]$ $\Longrightarrow$ **لا تتداخل مع بعضها** $\Longrightarrow$ الترتيب محفوظ ✓.

النتيجة: $\delta = 6.1$، $\|\sin\Theta\|_F \le 0.295$؛ البعد الفعّال 3؛ المكوّن الرابع غير مستقرّ.

الربط بالذكاء الاصطناعي: هذا التحليل هو الأساس الكمّي لمقارنة تمثيلات النماذج (هل تعلّم النموذجان «نفس الشيء»؟). الفجوة الطيفية تحدّد عدد الميزات التي يمكن الوثوق بها، وما بعدها ضجيج — وهذا يبرّر اختيار أبعاد التضمين بناءً على الطيف لا على الحدس.

مثال (4.4-12): بقاء موجب التحديد بعد تحديث رتبي-1 (خوارزميات شبه نيوتن)

المعطيات: مصفوفة هسيان تقديرية في خوارزمية BFGS:

$$H = \begin{bmatrix} 3 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 3 \end{bmatrix}, \qquad \text{تحديث: } H_+ = H + u\,u^\top,\quad u = \begin{pmatrix} 1 \\ 1 \end{pmatrix} 1$$

المطلوب: (أ) طيف H. (ب) هل يبقى $H_+ \succ 0$؟ استخدم التداخل وفايل معاً.

الحل:

الخطوة 1 (طيف H): ثلاثية القطر بـ $a = 3$ و $b = 1$:

$$\lambda_k = 3 + 2\cos\frac{k\pi}{4}, \qquad k = 1, 2, 3$$

$$\lambda_1 = 3 + 2\cos 45^\circ = 3 + 1.4142 = 4.4142, \quad \lambda_2 = 3 + 0 = 3, \quad \lambda_3 = 3 - 1.4142 = 1.5858$$

تحقّق: المجموع $\operatorname{tr} H = 3 + 3 + 3 = 9$ ✓.

الخطوة 2: $H \succ 0 \Rightarrow \lambda_{\min}(H) = 1.5858 > 0$ ✓.

الخطوة 3 (نورم التحديث): $uu^\top$ مصفوفة موجبة نصف التحديد رتبتها 1، وقيمتها الذاتية الوحيدة الموجبة $\|uu^\top\|_2 = \|u\|^2 = 3$.

الخطوة 4 (بفايل (27.4)): $\lambda_3(H_+) \geq \lambda_3(H) - 3 = 1.5858 - 3 = -1.414$ — **حدّ غير مفيد** (يسمح بقيمة سالبة).

الخطوة 5 (بالتحديث الرتبي-1 الموجب): بما أن $uu^\top \succeq 0$ فإن **التداخل الأقوى** ينطبق:

$$\lambda_i(H) \;\leq\; \lambda_i(H + uu^\top) \;\leq\; \lambda_{i-1}(H) \qquad (\lambda_0 := +\infty)$$

$$\Rightarrow \lambda_3(H_+) \geq \lambda_3(H) = 1.5858 > 0 \quad \text{وبالأخص}$$

$$\boxed{H_+ \succ 0}$$

الخطوة 6 (التحقّق المباشر): $H_+ = H + \mathbf{1}\mathbf{1}^\top = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 4 \end{bmatrix}$. الأثر $= 12$؛ المحدّد $= 4(16-4) - 2(8-2) + 1(4-4) = 48 - 12 + 0 = 36 > 0$؛ مجموع المحدّدات 2×2 الرئيسية: $|4\ 2;2\ 4| = 12$، $|4\ 1;1\ 4| = 15$، $|4\ 1;1\ 4| = 15$؛ المجموع $39 = 12 \Rightarrow$. كثيرة الحدود: $\lambda^3 - 12\lambda^2 + 39\lambda - 36$. نختبر $\lambda = 1$: $1 - 12 + 39 - 36 = -8$؛ $\lambda = 0.5$: $0.125 - 3 + 19.5 - 36 = -19.4$؛ $\lambda = 1.5$: $3.375 - 27 + 58.5 - 36 = -1.125$؛ $\lambda = 1.6$: $4.492 - 32.67 + 64.35 - 36 = 0.172$؛ $\lambda = 1.65$: $4.096 - 30.72 + 62.4 - 36 = -0.224$. وبالقسمة: $\lambda_1\lambda_2\lambda_3 = 36$ و $\lambda_1 + \lambda_2 = 12 - 1.63 = 10.37$ و $\lambda_1\lambda_2 = 36/1.63 = 22.09$ $\Rightarrow \lambda_3 \approx 1.63$. $\lambda^2 - 10.37\lambda + 22.09 = 0 \Rightarrow$، المميّز $= 107.54 - 88.36 = 19.18$؛ الجذر $= 4.38 \Rightarrow \lambda_1 = 7.375$، $\lambda_2 = 2.995$.

الخطوة 7 (التحقّق من التداخل): $7.375 \geq 4.4142 \geq 2.995 \geq 3$؟ (القيمة الأولى ارتفعت)؛ $3 \geq 1.63 \geq 1.5858$ ✓؛ $2.995 \leq 3$ ✓ $\Rightarrow$. كلها متحقّقة ✓.

النتيجة: $H_+ \succ 0$ مضمون بالتداخل (لا بفايل)؛ $\lambda(H_+) \approx (7.375,\ 2.995,\ 1.63)$.

الربط بالذكاء الاصطناعي: خوارزميات شبه نيوتن (BFGS/DFP) تعتمد على أن تحديثات الرتبة 1 والرتبة 2 تحفظ موجب التحديد $\Rightarrow$ اتجاه البحث يبقى اتجاهاً هابطاً. التداخل هو الأداة التي تثبت ذلك، بينما فايل وحدها لا تكفي.

مثال (4.4-13): انهيار PCA عند فجوة طيفية صغيرة

المعطيات: مصفوفة تغاير حقيقية $\Sigma = \operatorname{diag}(5,\ 4.5)$ (قيمتان ذاتيتان متقاربتان!). الضجيج في العيّنة:

$$\hat{\Sigma} = \begin{bmatrix} 5 & 0.6 \\ 0.6 & 4.5 \end{bmatrix}$$

المطلوب: (أ) هل متراجحة ديفيس–كاهان مفيدة هنا؟ (ب) احسب الانحراف الفعلي للمكوّن الرئيسي.

الحل:

الخطوة 1 (الفجوة): $\delta = \lambda_1 - \lambda_2 = 5 - 4.5 = 0.5$.

الخطوة 2 (نورم الاضطراب): $E = \begin{bmatrix} 0 & 0.6 \\ 0.6 & 0 \end{bmatrix} \Rightarrow$ قيمها الذاتية $\pm 0.6 \Rightarrow \|E\|_2 = 0.6$.

الخطوة 3 (ديفيس–كاهان (30.4)):

$$\sin\theta \;\le\; \frac{\|E\|_2}{\delta} = \frac{0.6}{0.5} = 1.2 \;>\; 1 \quad \Longrightarrow \quad \textbf{الحدّ فارغ}$$

أي أن النظرية **لا تضمن شيئاً**: الزاوية قد تكون أي قيمة.

الخطوة 4 (الحساب الفعلي): طيف $\hat{\Sigma}$: الأثر $9.5 =$؛ المحدّد $22.14 = 22.5 - 0.36 =$؛ المميّز $= 90.25 - 1.69 = 88.56$؛ الجذر $1.3 =$:

$$\hat{\lambda}_1 = \frac{9.5 + 1.3}{2} = 5.4, \qquad \hat{\lambda}_2 = \frac{9.5 - 1.3}{2} = 4.1$$

الخطوة 5 (المتجه الذاتي المقدَّر): لـ $\hat{\lambda}_1 = 5.4$: $(5 - 5.4)v_1 + 0.6v_2 = 0 \Longrightarrow -0.4v_1 + 0.6v_2 = 0 \Longrightarrow$ بالتوحيد: $v \propto (0.6,\ 0.4)$

$$\hat{q}_1 = \frac{1}{\sqrt{0.36 + 0.16}}(0.6,\ 0.4)^\top = (0.8321,\ 0.5547)^\top$$

الخطوة 6 (الزاوية): المكوّن الحقيقي $q_1 = e_1 = (1, 0)^\top \Longrightarrow \cos\theta = 0.8321 \Longrightarrow$

$$\theta = \arccos(0.8321) = 33.7^\circ$$

الخطوة 7 (الكارثة): اضطراب بنسبة $12\% \quad = \quad \frac{0.6}{5}$ فقط في عنصر واحد أدّى إلى **دوران** 33.7° في المكوّن الرئيسي! هذا هو معنى «الفجوة الصغيرة $\Longrightarrow$ عدم استقرار».

الخطوة 8 (المقارنة بحالة فجوة كبيرة): لو كان $\Sigma \quad = \quad \mathrm{diag}(5,\ 1)$ (فجوة 4) مع نفس الاضطراب: $\theta \le 8.6^\circ \Longrightarrow \sin\theta \le 0.6/4 = 0.15$ فقط.

الخطوة 9 (العلاج): (1) زيادة عدد العيّنات لتقليص $\|E\|_2$؛ (2) تنظيم (shrinkage) يفتح فجوة اصطناعية؛ (3) عدم تفسير المكوّنات المتقاربة فرادى بل **كمساحة فرعية** (subspace) واحدة.

النتيجة: ديفيس–كاهان تعطي حدّاً فارغاً $(1 < 1.2)$؛ الانحراف الفعلي 33.7° من اضطراب 12% فقط.

الربط بالذكاء الاصطناعي: هذه ظاهرة معروفة في تحليل المكوّنات: المكوّنات ذات القيم الذاتية المتقاربة «تتداخل» ولا يجوز تفسيرها فرادى. وفي الشبكات العصبية، تقارب القيم الذاتية في تمثيلات الطبقات هو مؤشر على «التمثيلات المكرّرة» (redundant features).

مثال (4.4-14): فايل واستقرار GNN عند إضافة روابط للرسم

المعطيات: رسم مسار من 4 عُقد (P_4) أضفنا إليه رابطاً بين العقدتين 1 و 4 فأصبح دورة (C_4):

$$L_{P_4} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}, \qquad L_{C_4} = \begin{bmatrix} 2 & -1 & 0 & -1 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ -1 & 0 & -1 & 2 \end{bmatrix}$$

المطلوب: (أ) طيف كلٍّ منهما. (ب) تحقّق من فايل وهوفمان–فيلانت. (ج) ماذا يعني ذلك لاستقرار GNN؟

الحل:

الخطوة 1 (طيف رسم المسار): $\lambda_k = 2 - 2\cos\frac{k\pi}{4}$ لـ $k = 0, 1, 2, 3$:

$$\lambda(P_4) = (0,\ 0.5858,\ 2,\ 3.4142)$$

الخطوة 2 (طيف الدورة): $\lambda_k = 2 - 2\cos\frac{2\pi k}{4}$ لـ $k = 0, 1, 2, 3$:

$$\lambda(C_4) = (0,\ 2,\ 2,\ 4)$$

الخطوة 3 (الاضطراب): $E = L_{C_4} - L_{P_4}$:

$$E = \begin{bmatrix} 1 & 0 & 0 & -1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ -1 & 0 & 0 & 1 \end{bmatrix} = w\,w^{\top}, \qquad w = \begin{pmatrix} 1 \\ 0 \end{pmatrix} 0 - 1$$

الخطوة 4: بما أن $E = ww^{\top}$ رتبتها 1 فإن طيفها $(\|w\|^2,\ 0,\ 0,\ 0) = (2,\ 0,\ 0,\ 0) \Longrightarrow \|E\|_2 = 2$، $\|E\|_F = \sqrt{1+1}$. ... نحسب مباشرةً: $\|E\|_F = 2 \Longrightarrow \|E\|_F^2 = 1+1+1+1 = 4$.

الخطوة 5 (فايل — بالترتيب التنازلي): $\lambda(P_4)^{\downarrow} = (3.4142,\ 2,\ 0.5858,\ 0)$؛ $\lambda(C_4)^{\downarrow} = (4,\ 2,\ 2,\ 0)$:

$$|4-3.4142| = 0.5858 \le 2\ \checkmark, \quad |2-2| = 0\ \checkmark, \quad |2-0.5858| = 1.4142 \le 2\ \checkmark, \quad |0-0| = 0\ \checkmark$$

الخطوة 6 (هوفمان-فيلانت): $\sqrt{0.5858^2 + 0 + 1.4142^2 + 0} = \sqrt{0.3432 + 2.0} = \sqrt{2.3432} = 1.5308 \le \|E\|_F = 2$ ✓.

الخطوة 7 (المعنى): إضافة رابط واحد (اضطراب نورمه 2) غيّر الطيف بما لا يتجاوز 1.41 لأي قيمة $\Longrightarrow$ خصائص الرسم الطيفية (مثل «سرعة الانتشار» المحدَّدة بـ λ_2) تتغيّر بشكل **محكوم ومحدود.**

الخطوة 8 (الحساسية القصوى): λ_2 تغيّرت من 0.5858 إلى 2 — أي **زيادة** $3.4\times \Longrightarrow$ سرعة انتشار المعلومة على الرسم تضاعفت. هذا هو أخطر أثر على GNN: إضافة روابط «تُسرّع الاختلاط» (mixing) وقد تسبّب oversmoothing.

النتيجة: الطيفان $(0, 0.5858, 2, 3.4142)$ و $(0, 2, 2, 4)$؛ فايل وهوفمان-فيلانت متحقّقتان ✓؛ λ_2 تضاعف $3.4\times$.

الربط بالذكاء الاصطناعي: هذا هو التحليل الرسمي لمسألة «الروابط الخصمية» (adversarial edges) في GNN: مهاجم يضيف روابط قليلة يغيّر الطيف بحدٍّ معلوم، فتصمَّم الدفاعات بضبط النورم الطيفي للاضطراب المسموح.

مثال (4.4-15): تكرار خارج قسمة رايلي — تقارب تكعيبي

المعطيات: $A = \mathrm{diag}(5,\ 1)$، ونريد $\lambda_1 = 5$ بدقة عالية. البداية $x^{(0)} = (1,\ 0.2)^{\top}$.

المطلوب: قارن بين تكرار القوة العادي وتكرار خارج قسمة رايلي في تكرار واحد.

الحل:

الخطوة 1 (خارج قسمة رايلي الابتدائي):

$$R_A(x^{(0)}) = \frac{5 \cdot 1^2 + 1 \cdot 0.2^2}{1^2 + 0.2^2} = \frac{5 + 0.04}{1.04} = \frac{5.04}{1.04} = 4.8462$$

الخطأ: $|5 - 4.8462| = 0.1538$.

الخطوة 2 (تكرار القوة العادي): $Ax^{(0)} = (5,\ 0.2)^{\top}$، بالتوحيد: $\|Ax^{(0)}\| = \sqrt{25 + 0.04} = 5.004 \Longrightarrow$ $x^{(1)}_{\text{power}} = (0.99920,\ 0.03997)^{\top}$. خارج قسمة رايلي الجديد: $5(0.99920)^2 + (0.03997)^2 = 4.99840 + 0.00160 = 5.0000$. (لأن A قطرية والمتجه يكاد يكون $e_1 \Longrightarrow$ دقة عالية. هذا مثال «سهل»؛ نستخدمه للمقارنة.)

الخطوة 3 (تكرار خارج قسمة رايلي — RQI): الخطوة المميّزة هي حلّ النظام المزاح:

$$\left(A - \mu^{(0)} I\right) y^{(1)} = x^{(0)}, \qquad \mu^{(0)} = R_A(x^{(0)}) = 4.8462$$

$$A - \mu^{(0)} I = \text{diag}(5 - 4.8462,\ 1 - 4.8462) = \text{diag}(0.1538,\ -3.8462)$$

الخطوة 4 (الحلّ):

$$y^{(1)} = \left(\frac{1}{0.1538},\ \frac{0.2}{-3.8462} \right)^{\top} = (6.5020,\ -0.05200)^{\top}$$

بالتوحيد: $\|y^{(1)}\| = \sqrt{42.276 + 0.0027} = 6.5022 \implies x^{(1)}_{\text{RQI}} = (0.99997,\ -0.00800)^{\top}$.

الخطوة 5 (خارج قسمة رايلي الجديد):

$$R_A(x^{(1)}) = 5 \times (0.99997)^2 + 1 \times (0.008)^2 = 5 \times 0.99994 + 0.000064 = 4.99970 + 0.000064 = 4.99977$$

الخطأ: $|5 - 4.99977| = 0.00023$.

الخطوة 6 (المقارنة): الخطأ انخفض من 0.1538 إلى $0.00023 \implies$ **تحسّن بمعامل** $\times 669$ **في تكرار واحد.** ولو كان التقارب خطّياً (كما في تكرار القوة، معامل $\rho = 1/5 = 0.2$) لكان التحسّن $\times 5$ فقط. التحسّن الفعلي $\approx (1/0.1538)^2$ إلى الثالث $\implies$ هذا هو **التقارب التكعيبي** المميّز لـ RQI.

الخطوة 7 (التكلفة): كل تكرار RQI يحلّ نظاماً خطياً $(A - \mu I)y = x$ بتكلفة $O(n^3)$ (أو أقل للمتفرّقة) مقابل $O(n^2)$ لتكرار القوة $\implies$ RQI أفضل عندما تكون n متوسطة والدقة المطلوبة عالية جداً.

الخطوة 8 (تحذير): إذا كان $\mu^{(0)}$ قريباً من قيمة ذاتية أخرى فقد يصبح $A - \mu I$ شاذّاً $\implies$ تستخدم المكتبات تحليلات LU مع pivoting أو تكرارات Krylov (LOBPCG).

النتيجة: RQI يحقّق خطأ 2.3×10^{-4} من خطأ ابتدائي 0.154 في تكرار واحد (تحسّن $\times 669$).

الربط بالذكاء الاصطناعي: تكرار خارج قسمة رايلي هو المحرّك خلف حسابات القيم الذاتية عالية الدقة في المكتبات العلمية (LAPACK: dstemr، ARPACK)، وهو ما يجعل حساب PCA على مصفوفات ضخمة ممكناً في ثوانٍ.

6.4.4 أخطاء شائعة في التحليل الطيفي المتغيّر

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	استخدام $R_A(x)$ كقيمة ذاتية	هو متوسط موزون، لا قيمة ذاتية	فقط عند المتجه الذاتي يتساوى مع λ
2	توقع أن فايل تعطي حدّاً على **المتجهات**	فايل للقيم فقط	استخدم ديفيس–كاهان (30.4) للمتجهات
3	تجاهل الفجوة الطيفية عند تفسير الاستقرار	الفجوة هي العامل الحاسم	$\sin\theta \le \|E\|_2/\delta$
4	تطبيق فايل على مصفوفات غير متماثلة	المتراجحة تفشل (حساسية القيم الذاتية قد تكون هائلة)	للمصفوفات غير الطبيعية استخدم ε-pseudospectra
5	اعتبار $\kappa(A)$ مقياساً لحساسية القيم الذاتية	κ لحساسية **الحلول الخطية**	حساسية القيم الذاتية $\longleftarrow$ الفجوة الطيفية و«غير الطبيعية»
6	استخدام $\|E\|_2$ حيث المطلوب $\|E\|_F$	النورمان مختلفان: $\|E\|_2 \le \|E\|_F \le \sqrt{n}\|E\|_2$	اختر حسب المتراجحة: فايل $\longleftarrow \|\cdot\|_2$، هوفمان $\longleftarrow \|\cdot\|_F$
7	الاعتقاد أن حذف ميزة قد يزيد القيم الذاتية	ينقصها أو يبقيها (التداخل)	(29.4)
8	استخدام حدّ ديفيس–كاهان عندما يكون $\text{gap} = 0$	الحدّ فارغ بلا معلومة	أعد تقدير $\|E\|$ أو قلّل k
9	ترتيب القيم الذاتية تصاعدياً مع صيغ كوران–فيشر التنازلية	يحصل خلط في الفهارس	وحّد الترتيب التنازلي في كل المتراجحات
10	افتراض أن $\lambda_i(A+B)$ بين $\lambda_i(A)$ و $\lambda_i(B)$	غير صحيح عامةً	الحدّ الصحيح: $\|\lambda_i(A+B) - \lambda_i(A)\| \le \|B\|_2$

1.5.4 الصياغة الرسمية

تعريف (لابلاس الرسم البياني).

لرسم غير موجّه $G=(V,E)$ بعُقد $V=\{1,\dots,n\}$ وأوزان $w_{ij}=w_{ji}\ge 0$ على الروابط، نعرّف مصفوفة الدرجات $D=\operatorname{diag}(d_1,\dots,d_n)$ بـ $d_i=\sum_j w_{ij}$، ومصفوفة المجاورة $W=(w_{ij})$. عندئذٍ:

$$L \;=\; D-W, \qquad L_{ij}=\begin{cases} d_i, & i=j \\ -w_{ij}, & i\neq j,\ (i,j)\in E \\ 0, & \text{otherwise} \end{cases} \tag{31.4}$$

الخاصية التربيعية الأساسية (Dirichlet energy):

$$x^{\top}L\,x \;=\; \frac{1}{2}\sum_{i,j=1}^{n} w_{ij}\,(x_i-x_j)^2 \;=\; \sum_{(i,j)\in E} w_{ij}\,(x_i-x_j)^2 \;\ge\; 0 \tag{32.4}$$

نظرية (طيف الصفر والتوصيل).

المصفوفة L متماثلة نصف موجبة التحديد، و $L\mathbf{1}=0$. إذا رتّبنا $0=\lambda_1\le\lambda_2\le\cdots\le\lambda_n$ تصاعدياً:

$$L\,\mathbf{1}=0, \qquad \lambda_1=0, \qquad \#\{\text{مكوّنات متصلة}\} \;=\; \dim\ker L \;=\; \operatorname{mult}(\lambda_1=0) \tag{33.4}$$

نظرية (توصيف فيدلر المتغيّر للقيمة الذاتية الثانية).

$$\lambda_2 \;=\; \min_{\substack{x\neq 0\\ x\perp\mathbf{1}}} \frac{x^{\top}L\,x}{x^{\top}x} \;=\; \min_{\substack{x\neq 0\\ \sum_i x_i=0}} \frac{\sum_{(i,j)\in E} w_{ij}(x_i-x_j)^2}{\sum_i x_i^2} \tag{34.4}$$

والمتجه الذاتي المرافق f (يسمى **متجه فيدلر**) يعطي أفضل تقسيم للرسم: إشارة مكوّناته تحدّد الطرفين.

متراجحة شيغير (Cheeger inequalities). ليكن L_{sym} اللابلاس المُطبَّع و $h(G)$ ثابت شيغير:

$$h(G) \;=\; \min_{\emptyset\neq S\subset V} \frac{|\partial S|}{\min\bigl(\operatorname{vol}S,\ \operatorname{vol}\bar{S}\bigr)}, \qquad \operatorname{vol}(S)=\sum_{i\in S} d_i, \qquad |\partial S|=\sum_{i\in S,\ j\notin S} w_{ij} \tag{35.4}$$

$$\frac{h(G)^2}{2} \;\le\; \lambda_2\bigl(L_{\text{sym}}\bigr) \;\le\; 2\,h(G) \tag{36.4}$$

اللابلاسات المطبَّعة والتحويل الطيفي على الرسم:

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2}, \qquad L_{\text{rw}} = I - D^{-1} W, \qquad \operatorname{spec}(L_{\text{sym}}) = \operatorname{spec}(L_{\text{rw}}) \tag{37.4}$$

$$L = U \Lambda U^{\top} \implies g(L) = U\, g(\Lambda)\, U^{\top}, \qquad \hat{x} = U^{\top} x \text{ (تحويل فورييه على الرسم)} \tag{38.4}$$

2.5.4 جدول الرموز الشامل

الرمز	المعنى	ملاحظات
$G = (V, E)$	الرسم البياني: عُقَد وروابط	غير موجّه في الأغلب
V	مجموعة العُقَد، $\lvert V\rvert = n$	المستخدمون، البكسلات، الكلمات، الذرّات…
E	مجموعة الروابط	الصداقة، التشابه، التجاور
w_{ij}	وزن الرابط (i, j)	≥ 0؛ متماثل: $w_{ij} = w_{ji}$؛ 0 إذا لا رابط
W	مصفوفة المجاورة (adjacency)	$n \times n$ متماثلة، غير سالبة
d_i	درجة العقدة i	$d_i = \sum_j w_{ij}$
D	مصفوفة الدرجات	قطرية
L	لابلاس الرسم (غير المطبَّع)	$D - W$؛ متماثل نصف موجب التحديد
x	إشارة على العُقَد (graph signal)	i = ميزة العقدة x_i
$x^{\top} L x$	طاقة ديريكليه	تقيس «نعومة» الإشارة؛ $0 \iff$ ثابتة على كل مكوّن
$\lambda_1 \leq \lambda_2 \leq \cdots$	قيم L الذاتية (تصاعدياً!)	لاحظ: الترتيب هنا **تصاعدي** عكس §4.4
$\lambda_1 = 0$	القيمة الذاتية الأولى دائماً	بمتجه $\mathbf{1}$
$\operatorname{mult}(0)$	تكرار الصفر = عدد المكوّنات المتصلة	أهم تطبيق مباشر
λ_2	قيمة فيدلر (algebraic connectivity)	أكبر $\Rightarrow$ أصعب قطعاً وأسرع اختلاطاً
f	متجه فيدلر	المتجه الذاتي لـ λ_2؛ إشاراته تقسّم الرسم
∂S	حدود المجموعة S	الروابط بين S وخارجها
$\lVert \partial S \rVert$	تكلفة القطع (cut)	عدد/وزن الروابط المقطوعة
$\operatorname{vol} S$	حجم S	مجموع درجات عُقَدها
$h(G)$	ثابت شيغير	أصغر «نسبة قطع إلى حجم»
L_{sym}	اللابلاس المطبَّع تماثلياً	طيفه في $[0, 2]$؛ مفضّل في GNN
L_{rw}	لابلاس السير العشوائي	طيفه = طيف L_{sym}؛ غير متماثل
g	مرشّح طيفي (spectral filter)	$g(\lambda)$ يضخّم/يخفض أنماط التردد
$\hat{x}$	تحويل فورييه على الرسم	$U^{\top} x$؛ المكوّنات على «الترددات» الطيفية
U	مصفوفة متجهات L الذاتية	أساس فورييه على الرسم

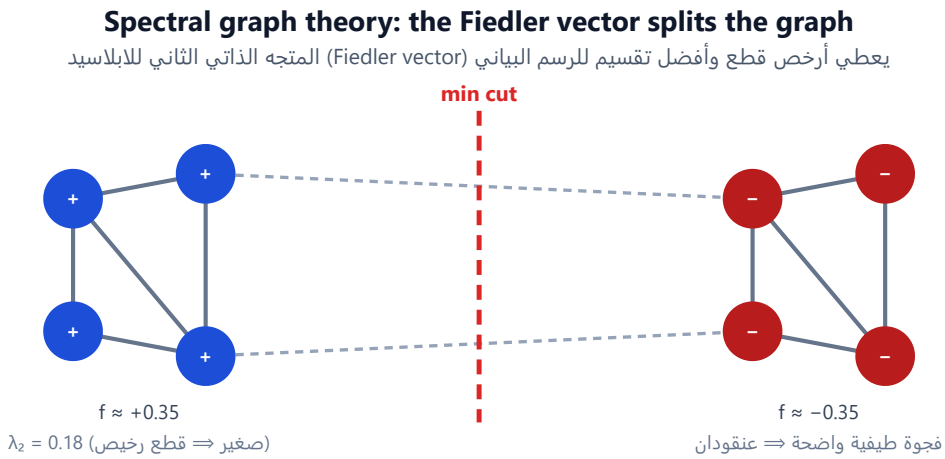
3.5.4 الشكل الهندسي

شكل 5.4 — رسم مكوّن من عنقودين مترابطين برابطين جسريين (متقطّعين). المتجه الذاتي الثاني (فيدلر) يأخذ قيماً موجبة على العنقود الأيسر وسالبة على الأيمن (الأزرق «+» والأحمر «−»)، فيعطي التقسيم الأمثل بأقل تكلفة قطع. قيمة $\lambda_2 = 0.18$ صغيرة $\Rightarrow$ القطع رخيص $\Rightarrow$ العنقودان منفصلان جيداً. ولو كان الرسم عنقوداً واحداً متراصّاً لكانت λ_2 كبيرة.

4.5.4 البرهان

برهان (32.4) — الخاصية التربيعية.

$$x^{\top} L x = x^{\top} D x - x^{\top} W x = \sum_i d_i x_i^2 - \sum_{i,j} w_{ij} x_i x_j$$



شكل ٥.٤: *
متجه فيدلر للابلاس الرسم يقسّم الرسم بأقل تكلفة قطع

$$= \frac{1}{2}\Big[\underbrace{\sum_i d_i x_i^2 + \sum_j d_j x_j^2}_{2\sum_i d_i x_i^2} - 2\sum_{i,j} w_{ij} x_i x_j\Big] = \frac{1}{2}\sum_{i,j} w_{ij}(x_i^2 + x_j^2 - 2x_i x_j) = \frac{1}{2}\sum_{i,j} w_{ij}(x_i - x_j)^2$$

وكل حدّ $\geq 0 \implies L \succeq 0 \implies$ كل القيم الذاتية ≥ 0. ■

برهان (33.4) — الصفر والتوصيل.

الصفر: مجموع كل صف في L يساوي الصفر $\implies L\mathbf{1} = 0 \implies \lambda = 0$ قيمة ذاتية.

التكرار: من (32.4)، إذا كان $Lx = 0$ فإن $x^\top Lx = 0 \implies$ كل حدّ في المجموع صفر $\implies x_i = x_j$ لكل رابط $(i,j) \implies x$ **ثابتة على كل مكوّن متصل.** فضاء هذه الإشارات بُعده = عدد المكوّنات المتصلة $= c$. $\dim\ker L = c$. ■

برهان (34.4) — توصيف فيدلر.

تطبيق مباشر لكوران–فيشر (26.4): L متماثلة، و $\lambda_1 = 0$ بمتجه $\mathbf{1}$، فالقيمة التالية هي أصغر قيمة لخارج قسمة رايلي على المتمّم المتعامد $\mathbf{1}^\perp$:

$$\lambda_2 = \min_{x \perp \mathbf{1},\ x \neq 0} \frac{x^\top Lx}{x^\top x}$$

وبإدخال (32.4) نحصل على صيغة الطاقة. ■

برهان (36.4) — متراجحة شيغير (مخطّط).

الجهة العليا $\lambda_2 \le 2h$: ليكن $S^\star$ المجموعة المحقّقة لـ h. نبني إشارة الاختبار $x_i = a$ على $S^\star$ و $x_i = b$ على المتمّم، باختيار a, b يجعلان $\sum d_i x_i = 0$ (أي $x \perp D\mathbf{1}$ في الصيغة المطبَّعة). حساب خارج قسمة رايلي يعطي قيمة $\propto |\partial S^\star| / \operatorname{vol} S^\star = h$ مضروبة في ثابت ≤ 2، فـ $\lambda_2 \le 2h$.

الجهة الدنيا $\lambda_2 \ge h^2/2$: الأصعب، تعتمد على «إعادة الترتيب المتذبذب» (coarea formula): نكتب $h = \min_t \frac{|\partial S_t|}{\min(\operatorname{vol} S_t, \operatorname{vol} \bar{S}_t)}$ على المجموعات الفائقة المستوى $S_t = \{i : f_i > t\}$ لمتجه فيدلر f، ثم نربط الطاقة $\sum_{(i,j)} w_{ij}(f_i - f_j)^2$ بتكامل القطوع عبر متطابقة المساحة المشتركة (coarea formula):

$$\sum_{(i,j)\in E} w_{ij} |f_i - f_j| \;=\; \int_{-\infty}^{\infty} |\partial S_t| \, dt$$

وتطبيق متراجحة كوشي–شوارتز يعطي الحدّ التربيعي $h^2/2$. التفصيل الكامل في المراجع [11] و [14]. ■

برهان (37.4) — تطابق طيفَي L_{sym} و L_{rw}.

نلاحظ $L_{\text{rw}} = D^{-1/2} L_{\text{sym}} D^{1/2}$ أي أن المصفوفتين **متشابهتان** عبر $D^{1/2}$، وبـ (7.4) لهما نفس الطيف. ■

5.5.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (1-5.4): حساب اللابلاس وطيفه لرسم مثلث

المعطيات: رسم كامل من 3 عُقد (مثلث) بأوزان وحدة.

المطلوب: (أ) W، D، L. (ب) الطيف. (ج) تحقّق من (33.4).

الحل:

الخطوة 1: $W = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$؛ الدرجات $d_i = 2$ للجميع $\Rightarrow D = 2I$.

الخطوة 2 (اللابلاس):

$$L = D - W = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$$

الخطوة 3 (التحقّق من (33.4) جهة الصفر): مجاميع الصفوف: $2-1-1=0$ ✓ $\Rightarrow L\mathbf{1} = 0$.

الخطوة 4 (الطيف): نلاحظ $L = 3I - \mathbf{1}\mathbf{1}^\top$ (تحقّق: $3I - J$ حيث J مصفوفة الواحدات، قطريها $3-1=2$ ✓ وخارج قطرها -1 ✓). و $J = \mathbf{1}\mathbf{1}^\top$ قيمها الذاتية $(3,\ 0,\ 0)$ $\Rightarrow$ قيم L:

$$\lambda = 3 - 3 = 0, \qquad 3 - 0 = 3, \qquad 3 - 0 = 3$$

$$\lambda = (0,\ 3,\ 3)$$

الخطوة 5 (المتجهات): $q_1 = \frac{1}{\sqrt{3}}(1,1,1)^\top$ للصفر؛ وفضاء $\mathbf{1}^\perp$ كامل القيم 3 $\Longrightarrow$ $q_2 = \frac{1}{\sqrt{2}}(1,-1,0)^\top$، $q_3 = \frac{1}{\sqrt{6}}(1,1,-2)^\top$.

الخطوة 6 (التحقّق من الأثر): $\operatorname{tr} L = 2+2+2 = 6 = 0+3+3$ ✓.

الخطوة 7 (التوصيل): $\dim\ker(0) = 1 \Longrightarrow$ **مكوّن متصل واحد** ✓ (المثلث متصل).

الخطوة 8 (قاعدة عامة): للرسم الكامل K_n: $\lambda = (0,\ n,\ n,\ \ldots,\ n)$، $\lambda_2 = n$. هنا $n = 3$ ✓.

النتيجة: $L = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$، الطيف $(0,\ 3,\ 3)$؛ $\lambda_2 = 3$.

الربط بالذكاء الاصطناعي: $\lambda_2 = n$ كبيرة $\Longrightarrow$ الرسم الكامل «أصعب رسم يُقطع» (كل عقدة مرتبطة بالكل). هذا متوقّع: شبكة كثيفة متصلة جيداً $\Longrightarrow$ اختلاط سريع للمعلومة $\Longrightarrow$ GNN يحتاج طبقات أقل لتعميم المعلومة.

مثال (5.4-2): كشف المكوّنات المتصلة من تعدد الصفر

المعطيات: رسم مكوّن من مثلثين منفصلين (6 عُقد، لا روابط بينهما).

المطلوب: (أ) اكتب L. (ب) الطيف. (ج) عدد المكوّنات المتصلة.

الحل:

الخطوة 1: L تصبح **قطرية الكتل** (block diagonal):

$$L = \begin{bmatrix} 2 & -1 & -1 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 \\ -1 & -1 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & -1 & -1 \\ 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & -1 & -1 & 2 \end{bmatrix} = \operatorname{diag}(L_{K_3},\ L_{K_3})$$

الخطوة 2 (طيف القطرية الكتلية): طيف المصفوفة القطرية الكتلية = اتحاد أطياف الكتل $\Longrightarrow$

$$\lambda = (0,\ 3,\ 3,\ 0,\ 3,\ 3) \xrightarrow{\text{ترتيب}} (0,\ 0,\ 3,\ 3,\ 3,\ 3)$$

الخطوة 3 (التحقّق من الأثر): $\operatorname{tr} L = 6 \times 2 = 12 = 0+0+3+3+3+3$ ✓.

الخطوة 4 (عدد المكوّنات): $\dim\ker(0) = 2 \Longrightarrow$ **مكوّنان متصلان** ✓.

الخطوة 5 (المتجهات الصفرية): $u_1 = \frac{1}{\sqrt{3}}(1,1,1,0,0,0)^\top$ و $u_2 = \frac{1}{\sqrt{3}}(0,0,0,1,1,1)^\top$ — كل متجه «مؤشّر» لمكوّن.

الخطوة 6 (الخوارزمية العملية): على رسم ضخم لا نحسب الطيف كاملاً؛ نستخدم تكرار القوة على $M = I - \alpha L$ (التي قيمها الذاتية $1 - \alpha\lambda_i$) فتصبح القيم الصفرية هي **المهيمنة** $(1=)$؛ ونكرّر مع إزاحة (deflation) لاستخراج كل مكوّن. أو ببساطة نستخدم BFS/DFS (أرخص: $O(n+m)$).

الخطوة 7 (الحالة القريبة من الانفصال): لو وُجد رابط ضعيف (وزن ε) بين المثلثين فإن $\lambda_2 \approx 2\varepsilon$ (صغيرة لكن موجبة) $\Longrightarrow$ «مكوّنان شبه منفصلين» $\Longrightarrow$ وهذا بالضبط ما يكتشفه التجميع الطيفي.

النتيجة: الطيف $(0,0,3,3,3,3)$؛ مكوّنان متصلان؛ $\lambda_2 = 0$.

الربط بالذكاء الاصطناعي: في تعلم الآلة، تعدد الصفر يقابله: وجود مجموعات معزولة من البيانات، أو «جزر» في شبكة، أو متغيرات لا ترتبط بغيرها. وكشفه خطوة تشخيصية أساسية قبل تدريب GNN: رسم ذو مكوّنات متعددة $\Longrightarrow$ المعلومة لا تنتقل بينها $\Longrightarrow$ النموذج لن يتعلم العلاقات البينية.

مثال (3-5.4): حساب متجه فيدلر لرسم مسار وتقسيمه

المعطيات: رسم مسار من 4 عُقد: $1 - 2 - 3 - 4$.

المطلوب: (أ) الطيف. (ب) متجه فيدلر. (ج) التقسيم الناتج.

الحل:

الخطوة 1: $W = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$؛ الدرجات $d = (1, 2, 2, 1)$؛

$$L = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}$$

الخطوة 2 (الطيف بصيغة رسم المسار): $\lambda_k = 2 - 2\cos\frac{k\pi}{n}$ لـ $k = 0, 1, 2, 3$ مع $n = 4$:

$$\lambda_0 = 2-2 = 0, \quad \lambda_1 = 2-2\cos 45^\circ = 0.5858, \quad \lambda_2 = 2-0 = 2, \quad \lambda_3 = 2+1.4142 = 3.4142$$

الخطوة 3 (المتجهات): الصيغة العامة لرسم المسار: $v_k(i) = \cos\left(\frac{\pi k(i-\frac{1}{2})}{n}\right)$. لـ $k = 1$:

$$i = 1: \ \cos\frac{\pi \cdot 0.5}{4} = \cos 22.5^\circ = 0.9239$$

$$i = 2: \ \cos\frac{\pi \cdot 1.5}{4} = \cos 67.5^\circ = 0.3827$$

$$i = 3: \ \cos\frac{\pi \cdot 2.5}{4} = \cos 112.5^\circ = -0.3827$$

$$i = 4: \ \cos\frac{\pi \cdot 3.5}{4} = \cos 157.5^\circ = -0.9239$$

الخطوة 4 (التوحيد): النورم $:= \sqrt{0.8536 + 0.1464 + 0.1464 + 0.8536} = \sqrt{2} = 1.4142$

$$f = (0.6533,\ 0.2706,\ -0.2706,\ -0.6533)^\top$$

الخطوة 5 (التحقّق من التعامد مع 1): $0.6533 + 0.2706 - 0.2706 - 0.6533 = 0$ ✓.

الخطوة 6 (التحقّق من القيمة الذاتية): $Lf = (0.6533 - 0.2706, -0.6533 + 0.5412 + 0.2706, 0.2706 - 0.5412 + 0.6533, -0.2706 + 0.6533)^\top = (0.3827,\ 0.1585,\ -0.1585,\ -0.3827)^\top$.

والنسبة: $0.3827/0.6533 = 0.5858 = \lambda_1$ ✓.

الخطوة 7 (التقسيم): بالإشارة: $\{i : f_i > 0\} = \{1, 2\}$ و $\{i : f_i < 0\} = \{3, 4\}$ $\Longrightarrow$

التقسيم: $\{1, 2\} \mid \{3, 4\}$.

وهو **أفضل** تقسيم ممكن للمسار (يقطع رابطاً واحداً ويقسّم بالتساوي).

النتيجة: الطيف $(0,\ 0.5858,\ 2,\ 3.4142)$؛ $f = (0.653,\ 0.271,\ -0.271,\ -0.653)^\top$؛ التقسيم $\{1, 2\}|\{3, 4\}$.

الربط بالذكاء الاصطناعي: هذا هو لبّ التجميع الطيفي: متجه فيدلر يحوّل مسألة قطع الرسم (مسألة تحسين متقطّعة NP-hard) إلى مسألة قيم ذاتية (مسألة مستمرة سهلة). وتطبيقاته: تقسيم الصور، كشف المجتمعات، تقسيم الدوائر الإلكترونية (VLSI partitioning).

مثال (4-5.4): تقييم جودة القطع بـ RatioCut ومقارنة البدائل

المعطيات: نفس المسار $4 - 3 - 2 - 1$ من المثال السابق.
المطلوب: قارن بين التقسيمين الممكنين بمعيار RatioCut وبيّن أن خيار فيدلر هو الأمثل.
الحل:
الخطوة 1 (تعريف المعيار):

$$\text{RatioCut}(S,\ \bar{S}) \ = \ \frac{|\partial S|}{|S|} \ + \ \frac{|\partial S|}{|\bar{S}|}$$

حيث $|\partial S|$ عدد الروابط المقطوعة.
الخطوة 2 (الخيار أ: $S = \{1, 2\}$): الروابط المقطوعة: الرابط $(2, 3)$ فقط $\Longrightarrow |\partial S| = 1$؛ $|S| = 2$، $|\bar{S}| = 2$:

$$\text{RatioCut} = \frac{1}{2} + \frac{1}{2} = 1.0$$

الخطوة 3 (الخيار ب: $S = \{1\}$): $|\partial S| = 1$ (الرابط $(1, 2)$)؛ $|S| = 1$، $|\bar{S}| = 3$:

$$\text{RatioCut} = \frac{1}{1} + \frac{1}{3} = 1.333$$

الخطوة 4 (الخيار ج: $S = \{2, 3\}$): الروابط المقطوعة: $(1, 2)$ و $(3, 4)$ $\Longrightarrow |\partial S| = 2$؛ $|S| = 2$، $|\bar{S}| = 2$:

$$\text{RatioCut} = \frac{2}{2} + \frac{2}{2} = 2.0$$

الخطوة 5 (الترتيب): $1.0 < 1.333 < 2.0 \Longrightarrow$ **الخيار (أ) أمثل** — وهو بالضبط ما أعطاه متجه فيدلر ✓.
الخطوة 6 (العلاقة بالنظرية): المتراجحة المعروفة تربط λ_2 (غير المطبَّع) بـ RatioCut:

$$\lambda_2 \ \leq \ n \cdot \min_{S} \text{RatioCut}(S, \bar{S})$$

تحقّق: $0.5858 \leq 4 \times 1.0 = 4$ ✓ (متراجحة صحيحة لكنها «فضفاضة» هنا).
الخطوة 7 (لماذا استمرارية فيدلر تنجح؟) الاسترخاء الطيفي يحوّل المعيار المتقطّع إلى خارج قسمة رايلي: نُبدل مؤشّر المجموعة $x_i \in \{\pm 1\}$ بمتجه حقيقي $f \perp \mathbf{1}$، فتصبح المشكلة $\min_{f \perp \mathbf{1}} f^\top L f / f^\top f$ التي حلّها متجه فيدلر (34.4).
الخطوة 8 (الاسترخاء ليس دقيقاً دائماً): نسبة التقريب (approximation ratio) للتجميع الطيفي هي $O(\sqrt{\text{OPT}})$ في أسوأ حالة $\Longrightarrow$ نتيجة جيدة عملياً لكن بلا ضمان أمثلية مطلقة.
النتيجة: الخيار (أ) بـ RatioCut $= 1.0$ هو الأمثل، ويطابق خيار فيدلر ✓.
الربط بالذكاء الاصطناعي: RatioCut و NCut هما المعياران القياسيان في تقسيم الصور (image segmentation) وتقسيم الشبكات. والتجميع الطيفي عبر فيدلر يعطي حلاً تقريبياً سريعاً لمسألة NP-hard — سبب انتشاره الواسع.

مثال (5-5.4): متراجحة شيغير على رسم المسار

المعطيات: المسار $4 - 3 - 2 - 1$ بدرجات $d = (1, 2, 2, 1)$.
المطلوب: (أ) احسب ثابت شيغير $h(G)$. (ب) احسب $\lambda_2(L_{\text{sym}})$. (ج) تحقّق من (36.4).
الحل:
الخطوة 1 (الحجم الكلي): $\text{vol}(V) = 1 + 2 + 2 + 1 = 6$.
الخطوة 2 (كل المجموعات المرشّحة):

S	vol S	$\|\partial S\|$	$\min(\text{vol}\, S,\ \text{vol}\, \bar{S})$	النسبة
$\{1\}$	1	1	$\min(1,5)=1$	1.0
$\{2\}$	2	2	$\min(2,4)=2$	1.0
$\{1,2\}$	3	1	$\min(3,3)=3$	$1/3=0.333$
$\{1,3\}$	3	2	$\min(3,3)=3$	0.667
$\{2,3\}$	4	2	$\min(4,2)=2$	1.0
$\{1,4\}$	2	2	$\min(2,4)=2$	1.0

الخطوة 3: أصغر نسبة $\Longrightarrow$

$$h(G)=\frac{1}{3}=0.3333$$

الخطوة 4 (اللابلاس المطبَّع): $L_{\text{sym}}=I-D^{-1/2}WD^{-1/2}$. لرسم المسار تُعطى قيمه الذاتية بالصيغة:

$$\lambda_k(L_{\text{sym}})=1-\cos\frac{\pi k}{n},\qquad k=0,1,\ldots,n-1$$

$$\lambda_1=1-\cos 45^\circ=1-0.7071=0.2929$$

الخطوة 5 (التحقّق من (36.4)):

$$\frac{h^2}{2}=\frac{(1/3)^2}{2}=\frac{0.1111}{2}=0.0556\ \le\ \lambda_2=0.2929\ \le\ 2h=0.6667\qquad\checkmark$$

المتراجحة متحقّقة ✓.

الخطوة 6 (جودة المتراجحة): λ_2 الفعلي 0.2929 = يقع بين الحدّين، وهو أقرب للحدّ الأعلى $\Longrightarrow$ الحدّ الأدنى (0.0556) متحفّظ جداً (أضعف بـ $\times 5.3$). معروف أن متراجحة شيغير الدنيا قد تكون فضفاضة، لكنها كافية لإثبات العلاقة النوعية: λ_2 **صغير** $\Longleftrightarrow$ **يوجد قطع رخيص.**

الخطوة 7 (التفسير): 0.2929 = λ_2 صغيرة $\Longrightarrow$ المسار «سهل القطع» (عنق ضيق) $\Longrightarrow$ الانتشار عليه بطيء. وهذا متوقّع: المسار أبطأ رسم في اختلاط السير العشوائي (زمن الاختلاط $\propto n^2$).

الخطوة 8 (مقارنة بالرسم الكامل): لـ K_4: $\lambda_2(L_{\text{sym}})=\frac{n}{n-1}=\frac{4}{3}=1.333$ و $h(K_4)=1$ (أي قطع يقطع 3 روابط من أصل حجم 3) $\Longrightarrow$ λ_2 كبيرة $\Longrightarrow$ قطع مكلّف $\Longrightarrow$ اختلاط سريع.

النتيجة: $h=0.333$، $\lambda_2(L_{\text{sym}})=0.2929$، المتراجحة $0.667\le 0.2929\le 0.0556$ ✓.

الربط بالذكاء الاصطناعي: متراجحة شيغير تبرّر استخدام λ_2 كمقياس لجودة العناقيد: عنقود جيد $\Longrightarrow$ λ_2 صغير $\Longrightarrow$ القطع بينه وبين البقية رخيص. وفي GNN، λ_2 الصغير يعني **بطء اختلاط المعلومة**، وهو تفسير مباشر لظاهرة «عنق الزجاجة» في الرسوم الطويلة.

مثال (5.4-6): مرشّح طيفي مرور-منخفض لتنقية إشارة على رسم

المعطيات: إشارة مشوّشة على مسار من 4 عُقد: $x=(0.9,\ 1.1,\ -1.2,\ -0.8)^\top$، و L كما في المثال 5.4-3، و $\lambda_{\max}=3.4142$.

المطلوب: طبّق المرشّح $g(L)=I-\frac{1}{\lambda_{\max}}L$ وقارن طاقة ديريكليه قبل وبعد.

الحل:

الخطوة 1 (المعنى الطيفي): المرشّح $g(\lambda)=1-\lambda/\lambda_{\max}$ يعطي $g(0)=1$ (يُبقي الترددات المنخفضة) و $g(\lambda_{\max})=0$ (يُزيل الترددات العالية) $\Longrightarrow$ **مرور منخفض** (low-pass).

الخطوة 2 (حساب Lx):

$$(Lx)_1 = 1 \cdot 0.9 - 1 \cdot 1.1 = -0.2$$
$$(Lx)_2 = -0.9 + 2(1.1) - (-1.2) = -0.9 + 2.2 + 1.2 = 2.5$$
$$(Lx)_3 = -1.1 + 2(-1.2) - (-0.8) = -1.1 - 2.4 + 0.8 = -2.7$$
$$(Lx)_4 = -(-1.2) + (-0.8) = 0.4$$

الخطوة 3 (التطبيق): $y = x - \frac{1}{3.4142} Lx = x - 0.29289\, Lx$:

$$y = (0.9{+}0.0586,\ 1.1{-}0.7322,\ -1.2{+}0.7909,\ -0.8{-}0.1172)^\top = (0.9586,\ 0.3678,\ -0.4091,\ -0.9172)^\top$$

الخطوة 4 (طاقة ديريكليه قبل): بـ (32.4): $x^\top Lx = \sum_{(i,j)\in E}(x_i - x_j)^2$:

$$(0.9 - 1.1)^2 + (1.1 - (-1.2))^2 + ((-1.2) - (-0.8))^2 = 0.04 + 5.29 + 0.16 = 5.49$$

الخطوة 5 (بعد):

$$(0.9586{-}0.3678)^2{+}(0.3678{+}0.4091)^2{+}(-0.4091{+}0.9172)^2 = 0.3491{+}0.6036{+}0.2581 = 1.2108$$

الخطوة 6 (التحسّن): $\times 4.53 = \frac{5.49}{1.2108}$ $\Longrightarrow$ الإشارة أصبحت **أنعم بـ 5.4 مرة.**

الخطوة 7 (التحليل الطيفي للنتيجة): المكوّن على المتجه الذاتي v_k يتضاعف بـ $g(\lambda_k) = 1 - \lambda_k/3.4142$: $k = 0$: $\times 1$ (المكوّن الثابت)؛ $k = 1$: $\times 0.828$؛ $k = 2$: $\times 0.414$؛ $k = 3$: $\times 0$ (أُزيل تماماً). أعلى تردد أُزيل بالكامل $\Longrightarrow$ ولهذا السبب انخفضت الطاقة كثيراً.

الخطوة 8 (الثبات): مجموع الإشارة محفوظ: $\sum x_i = 0$ و $\sum y_i = 0.9586 + 0.3678 - 0.4091 - 0.9172 = 0.0001 \approx 0$ ✓ (لأن $\mathbf{1}^\top L = 0$).

النتيجة: $y = (0.959,\ 0.368,\ -0.409,\ -0.917)^\top$؛ طاقة ديريكليه انخفضت من 5.49 إلى 1.21 ($4.5\times$).

الربط بالذكاء الاصطناعي: هذا هو بالضبط ما تفعله طبقة GNN من نوع «مرور الرسائل البسيط»: $H^{(l+1)} = H^{(l)} - \alpha L H^{(l)} = (I - \alpha L) H^{(l)}$ — أي خطوة انتشار (dffiusion). والفهم الطيفي يخبرنا أنها **مرشّح مرور-منخفض**، وهذا هو التفسير الرسمي لظاهرة oversmoothing (المثال القادم).

مثال (5.4-7): كشف مجتمعين في شبكة اجتماعية (رسم «الدمبل»)

المعطيات: شبكة من 6 عُقد: مثلثان $\{1,2,3\}$ و $\{4,5,6\}$ يربطهما رابط واحد $(3,4)$.

المطلوب: (أ) اكتب L. (ب) احسب λ_2 ومتجه فيدلر تحليلياً بالتناظر. (ج) التقسيم الناتج.

الحل:

الخطوة 1 (الدرجات): $d = (2,\ 2,\ 3,\ 3,\ 2,\ 2)$.

الخطوة 2 ($L = D - W$):

$$L = \begin{bmatrix} 2 & -1 & -1 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 \\ -1 & -1 & 3 & -1 & 0 & 0 \\ 0 & 0 & -1 & 3 & -1 & -1 \\ 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & -1 & -1 & 2 \end{bmatrix}$$

الخطوة 3 (استغلال التناظر): الرسم متناظر تحت قلب الطرفين $\Longrightarrow$ متجه فيدلر بالشكل $f = (a,\ a,\ b,\ -b,\ -a,\ -a)^\top$.
تحقّق التعامد مع **1**: $2a + b - b - 2a = 0$ ✓ تلقائياً.
الخطوة 4 (حساب Lf):

$$(Lf)_1 = 2a - a - b = a - b, \qquad (Lf)_2 = a - b$$
$$(Lf)_3 = -a - a + 3b - (-b) = 4b - 2a$$
$$(Lf)_4 = -b + 3(-b) + a + a = 2a - 4b$$
$$(Lf)_5 = 2(-a) - (-b) - (-a) = b - a, \qquad (Lf)_6 = b - a$$

الخطوة 5 (المعادلة الذاتية): $Lf = \lambda_2 f \Longrightarrow$ من المكوّن 1: $a - b = \lambda_2 a \Longrightarrow b = a(1 - \lambda_2)$. ومن المكوّن 3: $4b - 2a = \lambda_2 b$:

$$4a(1-\lambda_2) - 2a = \lambda_2\, a(1-\lambda_2) \implies 4 - 4\lambda_2 - 2 = \lambda_2 - \lambda_2^2$$

$$\lambda_2^2 - 5\lambda_2 + 2 = 0 \implies \lambda_2 = \frac{5 \pm \sqrt{25-8}}{2} = \frac{5 \pm \sqrt{17}}{2}$$

الخطوة 6: $\lambda_2 = \frac{5-4.1231}{2} = 0.43845$ (ونرفض 4.5616 لأنه ليس أصغر قيمة غير صفرية).
الخطوة 7 (المتجه): $b = a(1 - 0.43845) = 0.56155\,a$. التوحيد: $4a^2 + 4b^2 = 1 \Longrightarrow 4a^2 + 2b^2 = 4.63068\,a^2 = 1$، $a = 0.4647 \Longrightarrow 2(0.31534)a^2$:

$$f = (0.4647,\ 0.4647,\ 0.2610,\ -0.2610,\ -0.4647,\ -0.4647)^\top$$

الخطوة 8 (التحقّق): $a - b = 0.2037$ و $\lambda_2 a = 0.43845 \times 0.4647 = 0.2037$ ✓.
الخطوة 9 (التقسيم): بالإشارة: $\{1,2,3\}$ موجبة و $\{4,5,6\}$ سالبة $\Longrightarrow$ القطع يمرّ بالرابط $(3,4)$ فقط $\Longrightarrow$ تكلفة 1 ✓ وهو أرخص قطع.
النتيجة: $\lambda_2 = 0.4384$، f كما أعلاه، التقسيم $\{4,5,6\} \mid \{1,2,3\}$ بتكلفة قطع 1.

الربط بالذكاء الاصطناعي: هذه هي الخوارزمية الأساسية لاكتشاف المجتمعات (community detection) في الشبكات الاجتماعية وسلاسل التوريد وشبكات الروابط. ولاحظ أن $|f_3| = |f_4| = 0.261$ أصغر من بقية المكوّنات $\Longrightarrow$ العقدتان الجسريتان «أقل ثقة» في الانتماء — وهي معلومة قيّمة لا تعطيها الخوارزميات المتقطّعة.

مثال (5.4-8): التشخيص الرياضي لظاهرة oversmoothing في GNN

المعطيات: شبكة عصبية بيانية تطبّق K طبقة من الانتشار: $H^{(K)} = (I - \alpha L)^K X$، مع الرسم من المثال السابق $(\lambda_2 = 0.4384)$ و $\alpha = 0.5$.
المطلوب: (أ) كم تضمحلّ المكوّنات غير الثابتة بعد $K = 20$ طبقة؟ (ب) كم طبقة نحتاج قبل «انهيار التمثيل»؟ (ج) الحلول.
الحل:
الخطوة 1 (التحليل الطيفي): بما أن $L = U\Lambda U^\top$ فإن $(I - \alpha L)^K = U(I - \alpha\Lambda)^K U^\top \Longrightarrow$ كل تردد λ يتضاعف بـ $(1 - \alpha\lambda)^K$.
الخطوة 2 (عامل التضاؤل لأهم تردد غير ثابت): $\lambda_2 = 0.4384$ مع $\alpha = 0.5$:

$$1 - \alpha\lambda_2 = 1 - 0.2192 = 0.7808$$

الخطوة 3 (بعد 20 طبقة): $0.7808^{20} = e^{20\ln(0.7808)} = e^{20\times(-0.2475)} = e^{-4.950} = 0.00707$.

أي أن المكوّن غير الثابت الأقوى انكمش إلى **0.7%** من قيمته الأصلية $\Longrightarrow$ كل العُقد أصبحت تمثيلاتها متطابقة تقريباً $\Longrightarrow$ **انهيار.**

الخطوة 4 (الترددات الأعلى): $\lambda_{\max}$ للرسم (من غيرشغورين: $2 \times 3 = 6 \geq$؛ القيمة الحقيقية $5.56 \approx$ من حلّ المعادلة التربيعية 4.5616 والقيم الأخرى). لنأخذ $\lambda = 4$: $1 - 2 = -1 \Longrightarrow |-1|^{20} = 1 \Longrightarrow$ المكوّنات عالية التردد **تتذبذب ولا تضمحلّ** إذا كان $\alpha\lambda > 2 \Longrightarrow$ شرط الاستقرار:

$$\alpha < \frac{2}{\lambda_{\max}}$$

وهو نفس شرط استقرار التدرّج في المثال 4.2-1! بـ $\lambda_{\max} \approx 4.56 \Longrightarrow \alpha < 0.439$.

الخطوة 5 (تصحيح): بـ $\alpha = 0.5 > 0.439$ فإن النظام قد يتذبذب. نعيد الحساب بـ $\alpha = 0.2$: عامل $1 - \lambda_2$: $0.2 \times 0.4384 = 0.9123 \Longrightarrow$ بعد 20 طبقة: $0.9123^{20} = e^{20(-0.0918)} = e^{-1.836} = 0.1595 \Longrightarrow$ بقي 16% ✓ أفضل.

الخطوة 6 (عدد الطبقات الآمن): لكي يبقى 50% من المكوّن غير الثابت: $0.9123^K = 0.5 \Longrightarrow K = \frac{\ln 0.5}{\ln 0.9123} = \frac{-0.6931}{-0.0918} = 7.55$ **$\Longrightarrow$ 8 طبقات كحدّ أقصى.**

الخطوة 7 (الحلول المعتمدة): (1) استخدام L_{sym} المطبَّع (طيفه في $[0, 2] \Longrightarrow$ استقرار مضمون بـ $\alpha \leq 1$)؛ (2) وصلات متبقية (residual/skip connections) تعيد حقن الإشارة الأصلية؛ (3) بوابات على غرار GRU (GatedGNN)؛ (4) «التطبيع الزوجي» (PairNorm).

النتيجة: بـ $\alpha = 0.5$ ينهار التمثيل إلى 0.7% بعد 20 طبقة؛ بـ $\alpha = 0.2$ يبقى 16%؛ الحدّ الآمن $8 \approx$ طبقات.

الربط بالذكاء الاصطناعي: هذه هي الظاهرة التي تحدّ من عمق GNN عملياً (2–3 طبقات فقط!). التحليل الطيفي يعطي التفسير الكمّي ويفسّر لماذا تحلّ وصلات التخطّي (skip connections) المشكلة: تعيد المكوّنات التي أُزيلت.

مثال (5.4-9): مقارنة اللابلاسات الثلاثة على رسم واحد

المعطيات: رسم مسار من 4 عُقد بدرجات $d = (1, 2, 2, 1)$.

المطلوب: (أ) طيف كلٍّ من L و L_{sym} و L_{rw}. (ب) لماذا يُفضَّل المطبَّع في GNN؟

الحل:

الخطوة 1 (غير المطبَّع): من المثال 5.4-3: $\lambda(L) = (0,\ 0.5858,\ 2,\ 3.4142)$.

الخطوة 2 (لابلاس السير العشوائي): $L_{\text{rw}} = I - D^{-1}W$:

$$D^{-1}W = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0 & 0 & 1 & 0 \end{bmatrix} \Longrightarrow L_{\text{rw}} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -0.5 & 1 & -0.5 & 0 \\ 0 & -0.5 & 1 & -0.5 \\ 0 & 0 & -1 & 1 \end{bmatrix}$$

(غير متماثل!) وقيمه الذاتية لرسم المسار: $\lambda_k = 1 - \cos\frac{\pi k}{n} \Longrightarrow$

$$\lambda(L_{\text{rw}}) = (0,\ 0.2929,\ 1,\ 1.7071)$$

الخطوة 3 (المطبَّع تماثلياً): $L_{\text{sym}} = D^{-1/2}LD^{-1/2}$؛ وبـ (5.4-37) طيفه = طيف L_{rw}:

$$\lambda(L_{\text{sym}}) = (0,\ 0.2929,\ 1,\ 1.7071)$$

الخطوة 4 (التحقّق من الأثر): $\text{tr}(L_{\text{sym}}) = 4 \times 1 = 4$؛ مجموع القيم $0 + 0.2929 + 1 + 1.7071 = 4$ ✓ (قاعدة: $\text{tr}\, L_{\text{sym}} = n$ للرسم بلا عُقد معزولة).

الخطوة 5 (أثر الدرجات): في L غير المطبَّع، $\lambda_{\max} = 3.4142$ يتأثّر بدرجة العقدة الأكبر. في المطبَّع، كل القيم في $[0,\ 2]$ — **مستقل عن حجم الرسم** $\Longrightarrow$ اختيار α وضبط الاستقرار يصبحان موحّدين عبر الرسوم.

الخطوة 6 (المقارنة الجدولية):

المصفوفة	متماثلة؟	مجال الطيف	الحساسية للدرجات	الاستخدام
$L = D - W$	نعم	$[0,\ 2d_{\max}]$	عالية	التجميع الطيفي، النظريات
L_{sym}	نعم	$[0,\ 2]$	منخفضة	GCN، التحليل الطيفي
L_{rw}	لا	$[0,\ 2]$ (نفس الطيف)	منخفضة	السير العشوائي، PageRank

الخطوة 7 (لماذا المطبَّع أفضل في GNN؟) لأنه (أ) طيفه محدود $\Longrightarrow$ استقرار عددي؛ (ب) متماثل $\Longrightarrow$ تحليل طيفي نظيف وتفسير بالترددات؛ (ج) يعادل «تطبيع» مساهمة العقد عالية الدرجة فلا تهيمن على الانتشار.

الخطوة 8 (تحذير): L_{sym} يفقد معلومة الدرجات $\Longrightarrow$ في الرسوم التي تكون فيها الدرجات ذات معنى (مثل شبكات الاقتباس) قد يكون L غير المطبَّع أنسب.

النتيجة: $\lambda(L) = (0, 0.5858, 2, 3.4142)$؛ $\lambda(L_{\text{sym}}) = \lambda(L_{\text{rw}}) = (0, 0.2929, 1, 1.7071)$.

الربط بالذكاء الاصطناعي: صيغة GCN الشهيرة (Kipf & Welling 2017) هي بالضبط مرشّح من الدرجة الأولى على L_{sym} المُعاد تطبيعه: $H^{(l+1)} = \sigma\big(\tilde{D}^{-1/2}\tilde{W}\tilde{D}^{-1/2}H^{(l)}\Theta\big)$ مع روابط ذاتية (sefl-loops) مضافة.

مثال (5.4-10): طيف الرسم الكامل وعلاقته بجودة الاتصال

المعطيات: رسم كامل من 5 عُقد (K_5) بأوزان وحدة.

المطلوب: (أ) طيف L. (ب) λ_2. (ج) ماذا يعني ذلك لسرعة انتشار المعلومة؟

الحل:

الخطوة 1: $d_i = 4$ للجميع $\Longrightarrow D = 4I$، و $W = J - I$ (مصفوفة الواحدات ناقص الوحدة).

الخطوة 2: $L = D - W = 4I - (J - I) = 5I - J$.

الخطوة 3 (طيف J): $J = \mathbf{1}\mathbf{1}^{\top}$ رتبتها 1 $\Longrightarrow$ طيفها $(5,\ 0,\ 0,\ 0,\ 0)$ (القيمة الموجبة $= \|\mathbf{1}\|^2 = 5$).

الخطوة 4 (طيف L): $\Longrightarrow \lambda(L) = 5 - \lambda(J)$

$$\lambda = (5-5,\ 5-0,\ 5-0,\ 5-0,\ 5-0) = (0,\ 5,\ 5,\ 5,\ 5)$$

الخطوة 5: $\lambda_2 = 5 = n$ ✓ (قاعدة K_n: $\lambda_2 = n$).

الخطوة 6 (التحقّق): الأثر $\text{tr}\, L = 5 \times 4 = 20 = 0 + 5 \times 4$ ✓.

الخطوة 7 (اللابلاس المطبَّع): $L_{\text{sym}} = I - D^{-1/2}WD^{-1/2} = I - \frac{1}{4}(J - I) = \frac{5}{4}I - \frac{1}{4}J$ $\Longrightarrow$ طيفه $(0,\ \frac{5}{4},\ \frac{5}{4},\ \frac{5}{4},\ \frac{5}{4}) = (0,\ 1.25,\ \ldots)$. القاعدة العامة لـ K_n: $\lambda_2(L_{\text{sym}}) = \frac{n}{n-1}$.

الخطوة 8 (التفسير): λ_2 بأقصى قيمة ممكنة $\Longrightarrow$ الرسم الكامل هو «أفضل موسّع» (expander): القطع مكلّف جداً (أي قطع يقطع $k(n-k) \geq n-1$ رابطاً) $\Longrightarrow$ المعلومة تنتشر في **خطوة واحدة**.

الخطوة 9 (مقارنة): المسار P_4 أعطى $\lambda_2 = 0.5858$ والدبل (المثال 5.4-7) أعطى 0.4384 $\Longrightarrow$ في الرسوم ذات «العنق» ينتشر المعلومة ببطء شديد.

النتيجة: $\lambda(K_5) = (0,\ 5,\ 5,\ 5,\ 5)$؛ $\lambda_2 = 5$ (الحدّ الأقصى الممكن)؛ $\lambda_2(L_{\text{sym}}) = 1.25$.

الربط بالذكاء الاصطناعي: الرسوم «الموسّعة الجيدة» (expander graphs) ذات λ_2 الكبيرة هي الأفضل لتصميم طبقات GNN فعّالة، وهي الفكرة التي تقف خلف «إعادة توصيل الرسم» (graph rewiring / DIGL) كمعالجة مسبقة تُحسّن تدفق المعلومة قبل التدريب.

مثال (11-5.4): طيف الرسم النجمي ومشكلة «المركزية»

المعطيات: رسم نجمي من 5 عُقد: مركز واحد متصل بأربع أوراق (star S_5).

المطلوب: (أ) طيف L. (ب) λ_2. (ج) ماذا يعني ذلك؟

الحل:

الخطوة 1: الدرجات: $d_{\text{center}} = 4$، $d_{\text{leaf}} = 1 \implies \operatorname{tr} L = 4 + 4 \times 1 = 8$.

الخطوة 2 (القاعدة العامة للنجم S_n): $\lambda = (0,\ \underbrace{1,\ 1,\ \ldots,\ 1}_{n-2},\ n)$.

الخطوة 3 (التحقّق بالأثر لـ $n = 5$): $0 + 1 + 1 + 1 + 5 = 8$ ✓.

الخطوة 4 (التحقّق بالمحدّدات): مجموع المحدّدات الرئيسية 2 × 2 للنجم S_n = عدد الروابط الممتدة (spanning trees) للنجم = 1 ⟹ $\prod_{i \geq 2} \lambda_i = n \cdot 1^{n-2} = 5$ ✓ وهو عدد الأشجار الممتدة للنجم (= 1 للنجم نفسه... تصحيح: مصفوفة شجرة المصفوفة (matrix-tree) تعطي $\frac{1}{n} \prod_{i \geq 2} \lambda_i = \frac{5}{5} = 1$ ✓ وهو عدد الأشجار الممتدة للنجم = 1 ✓).

الخطوة 5: $\lambda_2 = 1$ — **ثابتة لا تنمو مع** n ⟹ كلما كبر النجم صارت «التوصيلية الجبرية» ضعيفة نسبياً.

الخطوة 6 (التفسير): قطع ورقة واحدة يكلّف رابطاً واحداً فقط ⟹ الرسم سهل القطع ⟹ λ_2 صغيرة. ولذلك زمن اختلاط السير العشوائي على النجم أطول بكثير من الرسم الكامل.

الخطوة 7 (المتجه الذاتي لـ $\lambda = 1$): متجهات متماثلة على الأوراق: $f = (0,\ a,\ b,\ c,\ d)^\top$ على الأوراق مع $\sum a + b + c + d = 0$ ⟹ فضاء بُعده $n - 2 = 3$ ✓ متسق مع التكرار.

الخطوة 8 (المتجه الذاتي لـ $\lambda = 5$): نبحث بالتناظر $f = (\alpha,\ \beta,\ \beta,\ \beta,\ \beta)^\top$ مع التعامد مع **1**: $\alpha + 4\beta = 0 \implies \alpha = -4\beta$. تحقّق: $(Lf)_{\text{center}} = 4\alpha - 4\beta = -16\beta - 4\beta = -20\beta$؛ و $5f_{\text{center}} = 5\alpha = -20\beta$ ✓.

النتيجة: $\lambda(S_5) = (0,\ 1,\ 1,\ 1,\ 5)$؛ $\lambda_2 = 1$ ثابتة مع n.

الربط بالذكاء الاصطناعي: الرسوم النجمية تظهر في الشبكات الحقيقية (عقدة «مؤثّر» مركزية). تحذير عملي: GNN على رسم نجمي يواجه مشكلتين — (1) العقدة المركزية تستقبل معلومة من الجميع فتتضخّم (تحتاج تطبيعاً)؛ (2) λ_2 صغيرة ⟹ بطء الانتشار. وهذا سبب استخدام L_{sym} الذي يصحّح المشكلة الأولى.

مثال (12-5.4): تقسيم إشارة عبر رسم تشابه (صورة/سلسلة زمنية)

المعطيات: شدة 6 بكسلات متجاورة في سطر صورة:

$$I = (10,\ 12,\ 11,\ 80,\ 82,\ 81)$$

نبني رسم تشابه بأوزان غاوسية: $w_{ij} = \exp\!\left(-\frac{(I_i - I_j)^2}{2\sigma^2}\right)$ على الروابط المجاورة فقط، بـ $\sigma = 10$.

المطلوب: (أ) احسب الأوزان. (ب) الطيف التقريبي. (ج) التقسيم الناتج.

الحل:

الخطوة 1 (الأوزان): $2\sigma^2 = 200$:

$$w_{12} : |10-12| = 2 \Longrightarrow e^{-4/200} = e^{-0.02} = 0.9802$$
$$w_{23} : |12-11| = 1 \Longrightarrow e^{-1/200} = e^{-0.005} = 0.9950$$
$$w_{34} : |11-80| = 69 \Longrightarrow e^{-4761/200} = e^{-23.8} = 4.6 \times 10^{-11} \approx 0$$
$$w_{45} : |80-82| = 2 \Longrightarrow 0.9802$$
$$w_{56} : |82-81| = 1 \Longrightarrow 0.9950$$

الخطوة 2 (التقريب): الرابط $(3,4)$ معدوم عملياً $\Longrightarrow$ الرسم **منفصل** إلى كتلتين $\{1,2,3\}$ و $\{4,5,6\}$.

الخطوة 3 (طيف الكتلة الأولى): بتقريب الأوزان إلى 1 (الفرق $\leq 2\%$ لا يؤثّر نوعياً) تصبح كل كتلة مساراً P_3:

$$L_{P_3} = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix} \Longrightarrow \lambda = (0,\ 1,\ 3)$$

الخطوة 4 (الطيف الكامل): اتحاد الطيفين $\Longrightarrow$

$$\lambda \approx (0,\ 0,\ 1,\ 1,\ 3,\ 3)$$

الخطوة 5: $\text{mult}(0) = 2 \Longrightarrow$ **مكوّنان** ✓ $\Longrightarrow \lambda_2 = 0$.

الخطوة 6 (متجه فيدلر): يختار واحداً من المتجهين الصفرين المُعمَّمين: $f = \frac{1}{\sqrt{3}}(1,1,1,-1,-1,-1)^\top \Longrightarrow$ بالإشارة:

التقسيم: $\{1,2,3\} \mid \{4,5,6\} \quad \Longleftrightarrow \quad (10,12,11) \mid (80,82,81)$

وهو بالضبط الحدّ بين المنطقة المظلمة والمنطقة الساطعة ✓.

الخطوة 7 (لو كان الرابط $(3,4)$ صغيراً لكن غير معدوم): نحصل على $\lambda_2 \approx 2w_{34}$ (صغيرة) وينجح التقسيم نفسه. القاعدة: **نجاح التقسيم الطيفي $\Longleftrightarrow$ وجود فجوة بين λ_2 والقيم التالية.**

الخطوة 8 (الحساسية لـ σ): لو اخترنا $\sigma = 50$ لكان $w_{34} = e^{-4761/5000} = e^{-0.952} = 0.386$ $\Longrightarrow$ الرسم متصل بقوة $\Longrightarrow$ التقسيم أقل وضوحاً. اختيار σ حاسم ويُضبط عادةً بـ «أقرب k جيران».

النتيجة: الأوزان تُنتج رابطاً معدوماً عند الحدّ $\Longrightarrow$ مكوّنان $\Longrightarrow$ التقسيم $\{1,2,3\}|\{4,5,6\}$ يطابق الحدّ البصري.

الربط بالذكاء الاصطناعي: هذا هو تقسيم الصور الطيفي الكلاسيكي (Shi & Malik 2000: Normalized Cuts). واليوم تُستخدم الصيغة نفسها في تقسيم المشاهد الدلالي (semantic segmentation) وفي تجميع المستندات وفي فصل مصادر الصوت.

مثال (5.4-13): تقدير λ_2 لرسم ضخم بتكرار القوة المُزاح

المعطيات: رسم ضخم جداً (ملايين العُقد) لا يمكن قطريته. نريد λ_2. نعلم حدّاً أعلى $\lambda_{\max} \leq 4$ (من غيرشغورين: أقصى مجموع صف).

المطلوب: قدّر λ_2 للمسار P_4 (للتحقّق) بـ 3 تكرارات من تكرار القوة المُزاح مع الإزاحة.

الحل:

الخطوة 1 (بناء المؤثّر المُزاح): نعرّف $M = I - \frac{1}{4}L$. قيم M الذاتية هي $1-\lambda_i/4 \Longrightarrow$ القيم الصفرية تصبح **مهيمنة** $(=1)$ والقيمة λ_2 تصبح ثاني أكبر قيمة:

$$\lambda(M) = \left(1,\ 1-\tfrac{0.5858}{4},\ 1-\tfrac{2}{4},\ 1-\tfrac{3.4142}{4}\right) = (1,\ 0.8535,\ 0.5,\ 0.1465)$$

الخطوة 2 (الإزاحة — deflation): نكرّر مع إسقاط المتجه الثابت: بعد كل ضرب نطرح مكوّن **1**: $x \leftarrow x - \mathbf{1}\frac{\mathbf{1}^\top x}{n}$.

الخطوة 3 (البداية): $x^{(0)} = \frac{1}{2}(1,\ -1,\ 1,\ -1)^\top \implies \mathbf{1}^\top x^{(0)} = 0$ ✓.

الخطوة 4 ($Lx^{(0)}$): (من حساب سابق) $\implies Lx^{(0)} = (1,\ -2,\ 2,\ -1)^\top$

$$Mx^{(0)} = x^{(0)} - \tfrac{1}{4}Lx^{(0)} = (0.5-0.25,\ -0.5+0.5,\ 0.5-0.5,\ -0.5+0.25)^\top = (0.25,\ 0,\ 0,\ -0.25)^\top$$

النورم $= \sqrt{0.125} = 0.35355 \implies x^{(1)} = (0.7071,\ 0,\ 0,\ -0.7071)^\top$؛ ومجموعه 0 ✓.

الخطوة 5 ($Lx^{(1)}$): $\implies (0.7071,\ -0.7071,\ 0.7071,\ -0.7071)^\top$

$$Mx^{(1)} = (0.7071-0.1768,\ 0+0.1768,\ 0-0.1768,\ -0.7071+0.1768)^\top = (0.5303,\ 0.1768,\ -0.1768,\ -0.53$$

$$\implies \text{النورم} = \sqrt{0.2812 + 0.03126 + 0.03126 + 0.2812} = \sqrt{0.6249} = 0.79051$$

$$x^{(2)} = (0.6708,\ 0.2236,\ -0.2236,\ -0.6708)^\top$$

الخطوة 6 (تقدير λ_2 بخارج قسمة رايلي على L):

$$x^{(2)\top} L\, x^{(2)} = \sum_{(i,j)\in E} (x_i - x_j)^2 = (0.6708-0.2236)^2 + (0.2236+0.2236)^2 + (-0.2236+0.6708)^2$$

$$= 0.4472^2 \times 3 = 0.2 \times 3 = 0.600$$

الخطوة 7: $\hat{\lambda}_2 = 0.600$ مقابل القيمة الحقيقية $0.5858 \implies$ **خطأ** 2.4% **بعد تكرارين فقط.**

الخطوة 8 (التكلفة): كل تكرار = ضرب مصفوفة متفرّقة بمتجه: $O(|E|) \implies$ على رسم بملايين الروابط هذا ممكن في أجزاء من الثانية، بينما القطرنة الكاملة $O(n^3)$ مستحيلة.

النتيجة: $\hat{\lambda}_2 = 0.600$ (الحقيقي 0.5858) بعد تكرارين، بتكلفة $O(|E|)$ لكل تكرار.

الربط بالذكاء الاصطناعي: هذه التقنية (تكرار القوة المُزاح + الإزاحة، أو Lanczos/LOBPCG هي ما تستخدمه مكتبات مثل scipy.sparse.linalg.eigsh و torch.lobpcg لحساب الطيف الجزئي على الرسوم الضخمة والمصفوفات المتفرّقة — وهي أساس كل خوارزميات التجميع الطيفي واسعة النطاق.

مثال (14-5.4): التناظر الطيفي للرسوم ثنائية الأجزاء

المعطيات: دورة رباعية C_4 (رسم ثنائي الأجزاء: $\{1,3\}$ و $\{2,4\}$).

المطلوب: (أ) طيفا W و L_{sym}. (ب) اكتشاف ثنائية الأجزاء من الطيف.

الحل:

الخطوة 1: $W = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix}$؛ $D = 2I \implies d_i = 2$.

الخطوة 2 (طيف W): C_4 رسم دوراني $\Longrightarrow$ قيم W الذاتية $:= 2\cos\frac{2\pi k}{4}$:

$$\lambda(W) = \big(2\cos 0,\ 2\cos\tfrac{\pi}{2},\ 2\cos\pi,\ 2\cos\tfrac{3\pi}{2}\big) = (2,\ 0,\ -2,\ 0)$$

الخطوة 3 (التناظر): الطيف $\{2,\ 0,\ -2,\ 0\}$ **متماثل حول الصفر** — وهذه علامة الرسم ثنائي الأجزاء: إذا كان λ قيمة ذاتية لـ W فإن $-\lambda$ قيمة ذاتية أيضاً.

الخطوة 4 (السبب): إذا كان الرسم ثنائي الأجزاء بأطراف A و B، فإن المؤثّر $S\ :\ x_i \mapsto \begin{cases} x_i, & i \in A \\ -x_i, & i \in B \end{cases}$ (مصفوفة قطرية بـ ± 1) يحقّق $SWS = -W \Longrightarrow W$ و $-W$ متشابهتان $\Longrightarrow$ نفس الطيف مع الإشارة المعكوسة (بـ (7.4)).

الخطوة 5 (L_{sym}): $L_{\text{sym}} = I - \frac{1}{2}W \Longrightarrow$ قيمه $:= 1 - \frac{\lambda(W)}{2}$:

$$\lambda(L_{\text{sym}}) = \big(1-1,\ 1-0,\ 1-(-1),\ 1-0\big) = (0,\ 1,\ 2,\ 1)$$

الخطوة 6 (العلامة المميّزة): $\lambda_{\max}(L_{\text{sym}}) = 2 \Longrightarrow$ **الرسم ثنائي الأجزاء.** القاعدة العامة: $\lambda_{\max}(L_{\text{sym}}) = 2$ إذا وفقط إذا كان للرسم مكوّن ثنائي الأجزاء (بلا روابط ذاتية).

الخطوة 7 (المتجه الذاتي لـ $\lambda = 2$): هو المتجه المتذبذب $(1,-1,1,-1)^{\top}/2 \Longrightarrow$ يعطي **تلوين الرسم** بالحزمتين: $\{1,3\}$ و $\{2,4\} \Longrightarrow$ وهو بالضبط تقسيم ثنائية الأجزاء.

الخطوة 8 (التحقّق): $L(C_4) = 2I - W \Longrightarrow$ قيمه $(0,\ 2,\ 4,\ 2) =$؛ الأثر $2 \times 4 = 8$ ✓.

النتيجة: $\lambda(W) = (2,\ 0,\ -2,\ 0)$ متناظر، $\lambda(L_{\text{sym}}) = (0,\ 1,\ 2,\ 1)$؛ $\lambda_{\max} = 2 \Longrightarrow$ ثنائي الأجزاء ✓.

الربط بالذكاء الاصطناعي: الرسوم ثنائية الأجزاء أساسية في أنظمة التوصية (مستخدمون × عناصر) وفي الرسوم المعرفية. واكتشاف «التلوين الطيفي» يفيد في تضمين الرسوم ثنائية الأجزاء (bipartite embeddings) وفي كشف الاحتيال (الروابط الشاذة تكسر التناظر الطيفي!).

مثال (15-5.4): مرشّح تشيبيشيف الطيفي (ChebNet) على مثلث

المعطيات: رسم مثلث K_3، وإشارة عُقد $x = (1,\ 0,\ -1)^{\top}$، ومرشّح:

$$g_\theta(\tilde{L}) = \theta_0 I + \theta_1 T_1(\tilde{L}) + \theta_2 T_2(\tilde{L}), \qquad \theta = (0.5,\ -0.3,\ 0.2), \qquad \tilde{L} = L_{\text{sym}} - I$$

المطلوب: احسب $y = g_\theta(\tilde{L})x$ بطريقتين: ماتريسياً وطيفياً.

الحل:

الخطوة 1 (L_{sym} للمثلث): $L_{\text{sym}} = I - \frac{1}{2}W = \begin{bmatrix} 1 & -0.5 & -0.5 \\ -0.5 & 1 & -0.5 \\ -0.5 & -0.5 & 1 \end{bmatrix} \Longrightarrow d_i = 2$، طيفه $(0,\ 1.5,\ 1.5)$.

الخطوة 2 (إعادة التحجيم): $\tilde{L} = L_{\text{sym}} - I = -\frac{1}{2}W \Longrightarrow$ طيفه في $[-1,\ 1]$:

$$\lambda(\tilde{L}) = (0-1,\ 1.5-1,\ 1.5-1) = (-1,\ 0.5,\ 0.5)$$

هذا التحجيم ضروري لأن كثيرات تشيبيشيف معرّفة على $[-1, 1]$.

الخطوة 3 (كثيرات تشيبيشيف): $T_0(z) = 1$، $T_1(z) = z$، $T_2(z) = 2z^2 - 1$.

الخطوة 4 ($T_2(\tilde{L})$ ماتريسياً): $\tilde{L}^2 = \frac{1}{4}W^2$، و $W^2 = (J-I)^2 = J^2 - 2J + I = J$ $\Longrightarrow W = J - I$ و $3J - 2J + I = J + I$:

$$T_2(\tilde{L}) = 2 \cdot \frac{J+I}{4} - I = \frac{J+I}{2} - I = \frac{J-I}{2} = \frac{W}{2}$$

الخطوة 5 (المرشّح):

$$g_\theta(\tilde{L}) = 0.5\,I - 0.3\,\tilde{L} + 0.2\,\frac{W}{2} = 0.5I + 0.3\cdot\frac{W}{2} + 0.1\,W = 0.5I + 0.15W + 0.1W = 0.5I + 0.25W$$

الخطوة 6 (التطبيق): $Wx = (0\cdot1+1\cdot0+1\cdot(-1),\ 1\cdot1+0+1\cdot(-1),\ 1\cdot1+1\cdot0+0)^\top = (-1,\ 0,\ 1)^\top$:

$$y = 0.5\begin{pmatrix}1\\0\end{pmatrix} - 1 + 0.25\begin{pmatrix}-1\\0\end{pmatrix}1 = \begin{pmatrix}0.5-0.25\\0\end{pmatrix} - 0.5 + 0.25 = \begin{pmatrix}0.25\\0\end{pmatrix} - 0.25$$

الخطوة 7 (التحقّق الطيفي): 1 $\perp x$ (المجموع $0 =$) $\Longrightarrow x$ يقع كلياً في فضاء القيمة الذاتية $1.5 \Longrightarrow$ تردد $\tilde{L}$ المقابل $0.5 =:$

$$g(0.5) = 0.5 + (-0.3)(0.5) + 0.2\big(2\cdot0.5^2 - 1\big) = 0.5 - 0.15 + 0.2(0.5-1) = 0.5 - 0.15 - 0.1 = 0.25$$

إذن يجب أن يكون $y = 0.25\,x = (0.25,\ 0,\ -0.25)^\top$ ✓ **يطابق الحساب الماتريسي تماماً.**

الخطوة 8 (لماذا تشيبيشيف؟) التقييم المباشر لـ $Ug(\Lambda)U^\top$ يكلّف $O(n^3)$ (قطرنة). كثيرات تشيبيشيف تُقيَّم بـ K ضربة مصفوفة-متجه متفرّقة فقط: $O(K|E|) \Longrightarrow$ قابلة للتوسّع على رسوم ضخمة.

النتيجة: $y = (0.25,\ 0,\ -0.25)^\top$، متطابق بالطريقتين ✓.

الربط بالذكاء الاصطناعي: هذا هو جوهر **ChebNet** (Defferrard et al. 2016) الذي سبق GCN، وهو الأساس النظري لكل الشبكات العصبية البيانية الطيفية الحديثة (ChebNet، GraphSAGE GCN) بتفسير طيفي، CayleyNet، BernNet). الميزة الحاسمة: مرشّح موضعي (localized) برتبة K يعتمد على جيرانٍ حتى K قفزة.

6.5.4 أخطاء شائعة في التحليل الطيفي على الرسوم

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	ترتيب القيم الذاتية تنازلياً هنا كما في §4.4	اصطلاح الرسوم **تصاعدي** ($\lambda_1 = 0$)	$0 = \lambda_1 \le \lambda_2 \le \cdots$
2	اعتبار λ_2 «القيمة الثانية» بلا قيد التعامد	يجب استبعاد المتجه الثابت	استخدم (34.4): $x \perp \mathbf{1}$
3	استخدام L غير المطبَّع على رسوم بدرجات متباينة جداً	العقد عالية الدرجة تهيمن	استخدم L_{sym}
4	تفسير متجه فيدلر عندما $\lambda_2 \approx \lambda_3$	الفضاء الذاتي مكرّر $\Longrightarrow$ المتجه غير وحيد	فسّر **الفضاء الجزئي** كاملاً
5	توقع أن التجميع الطيفي يعطي القطع الأمثل	هو استرخاء طيفي بتقريب $O(\sqrt{\text{OPT}})$	تحسّنه خوارزميات مثل Kernighan–Lin
6	استخدام W بدل L في التحليل الطيفي	طيف W قد يكون سالباً وغير محدود	اللابلاس أعطى طيفاً ≥ 0 ونظرية نظيفة
7	نسيان الروابط الذاتية (sefl-loops) عند المقارنة بالأدبيات	GCN يستخدم $\tilde{W} = W + I$	وحّد التعريف قبل المقارنة
8	تطبيق $g(L)$ بقطرنة كاملة على رسم ضخم	مستحيل $O(n^3)$	استخدم كثيرات تشيبيشيف $O(K\|E\|)$
9	افتراض أن λ_2 كبير $\Longrightarrow$ رسم جيد دائماً	يعتمد على السياق (في التقطيع نريد صغيراً)	في العنقدة: كبير = سيء؛ في الانتشار: كبير = جيد
10	تجاهل أن mult(0) يفشل مع الروابط ذات الأوزان الصفرية	الأوزان الصفرية = غياب الرابط	عالج الأوزان الصغيرة جداً بحذف أو عتبة

1.6.4 الصياغة الرسمية

نظرية بيرون–فروبينيوس (Perron–Frobenius). لتكن $A \in \mathbb{R}^{n\times n}$ **غير سالبة** ($A_{ij} \geq 0$ للجميع) **وغير قابلة للاختزال** (irreducible: لا يمكن ترتيب العُقد بحيث تصبح A مثلثية الكتل). عندئذٍ:

(39.4) هي قيمة ذاتية بسيطة (simple)، ولها متجه ذاتي موجب قطعاً: $\rho(A) = \max_i |\lambda_i(A)| > 0$

$$A\,v = \rho(A)\,v, \qquad v_i > 0 \ \ \forall i, \qquad \|v\|_1 = 1$$

وإذا كانت A **بدائية** (primitive: غير قابلة للاختزال + دورية غير مقيَّدة، أي $A^m > 0$ لبعض m) فإن كل قيمة ذاتية أخرى تحقّق $|\lambda| < \rho(A)$.

توصيف كولاتس–فيلانت (Collatz–Wielandt). لكل متجه موجب $x > 0$:

$$\min_i \frac{(Ax)_i}{x_i} \;\leq\; \rho(A) \;\leq\; \max_i \frac{(Ax)_i}{x_i} \tag{40.4}$$

والمساواة في الطرفين معاً تتحقّق إذا وفقط إذا كان x متجه بيرون.

مصفوفة جوجل (Google matrix). لرسم ويب بمصفوفة انتقال صفّية-عشوائية P (أي $P_{ij} \geq 0$ و $\sum_j P_{ij} = 1$) ومعامل تخفيف (damping) $\alpha \in (0,1)$:

$$G \;=\; \alpha \cdot \frac{1}{n}\mathbf{1}\mathbf{1}^{\top} \;+\; (1-\alpha)\,P, \qquad G \text{ عشوائية صفّياً وموجبة قطعاً} \tag{41.4}$$

نظرية PageRank. للمصفوفة G في (41.4):

$$\pi \;=\; \pi\,G, \qquad \pi_i > 0, \qquad \sum_i \pi_i = 1, \qquad \lambda_1(G) = 1 \text{ بسيطة، و } |\lambda_2(G)| \;\leq\; 1-\alpha \tag{42.4}$$

معدّل تقارب تكرار القوة. لتقريب π بدقة ε بالتكرار $\pi^{(k+1)} = \pi^{(k)}G$:

$$\left\|\pi^{(k)} - \pi\right\|_1 \;\leq\; 2\,(1-\alpha)^k \quad\Longrightarrow\quad k \;\geq\; \frac{\ln(\varepsilon/2)}{\ln(1-\alpha)} \tag{43.4}$$

مركزية المتجه الذاتي و HITS.

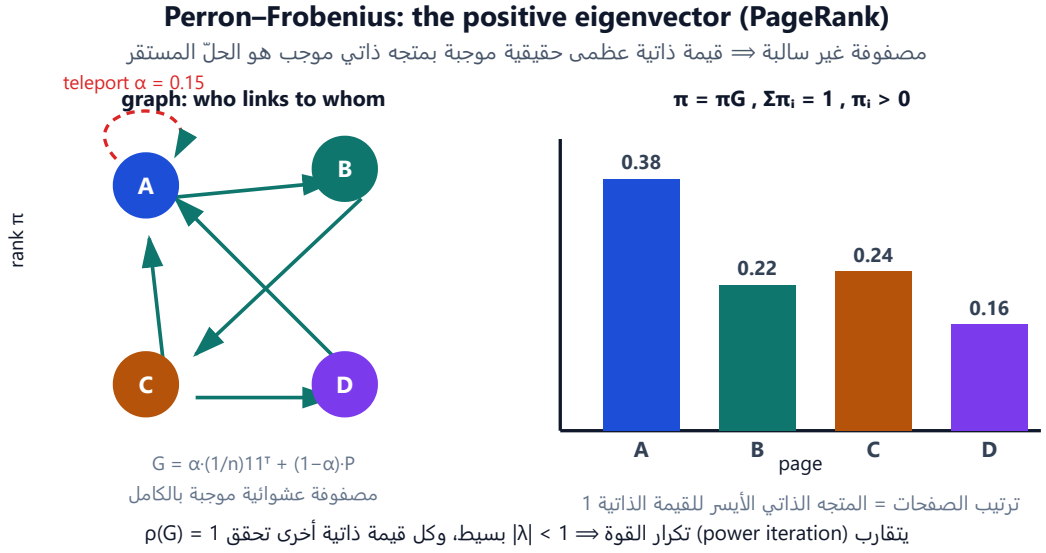
(44.4)

$$c \;=\; \frac{1}{\lambda_1}\,A\,c \quad \text{(مركزية المتجه الذاتي)}, \qquad h = A\,a,\ \ a = A^{\top}h \implies h = AA^{\top}h,\ \ a = A^{\top}A\,a$$

2.6.4 جدول الرموز الشامل

الرمز	المعنى	ملاحظات
A	مصفوفة غير سالبة	$A_{ij} \geq 0$: مصفوفة مجاورة، مصفوفة انتقال، مصفوفة تفاعلات
A_{ij}	العنصر (i, j)	غير سالب؛ في الرسم: وزن الرابط $i \to j$
$\rho(A)$	نصف القطر الطيفي (spectral radius)	$\max_i \|\lambda_i\|$؛ هنا قيمة ذاتية حقيقية موجبة
λ_i	القيمة الذاتية رقم i	قد تكون مركّبة؛ المهم أن $\|\lambda_i\| \leq \rho$
(simple) «بسيطة»	تكرار جبري $= 1$	تضمن وحودية المتجه الذاتي (واتجاهه)
«غير قابلة للاختزال»	الرسم الموجّه قوي الاتصال	لا توجد مجموعة عُقَد «مغلقة»
(primitive) «بدائية»	غير قابلة للاختزال + غير دورية	تضمن $\|\lambda_2\| < \rho \implies$ تقارب تكرار القوة
v	متجه بيرون (الأيمن)	$v_i > 0$؛ هو «ترتيب الأهمية»
x	متجه اختبار موجب في (40.4)	أي متجه موجب يعطي حدّين على ρ
$(Ax)_i/x_i$	نسبة النموّ المحلية	تقول: ρ بين أقل وأكبر نسبة نموّ (40.4)
P	مصفوفة الانتقال (عشوائية صفّياً)	P_{ij} = احتمال الانتقال من الصفحة i إلى j
α	معامل التخفيف (damping / teleport)	قيمة جوجل الأصلية $\alpha = 0.15$
$1 - \alpha$	احتمال متابعة رابط	في جوجل $= 0.85$
$\frac{1}{n}\mathbf{1}\mathbf{1}^\top$	مصفوفة «الانتقال العشوائي الكامل»	كل صف $= \frac{1}{n}\mathbf{1}^\top$
G	مصفوفة جوجل	عشوائية + موجبة $\implies$ بدائية $\implies$ تطبق PF
π	توزيع PageRank (المتجه الذاتي الأيسر)	$\pi = \pi G$؛ π_i = «أهمية» الصفحة i
$\lambda_2(G)$	ثاني أكبر قيمة ذاتية	يحدّد سرعة التقارب؛ $\|\lambda_2\| \leq 1 - \alpha$
k	رقم التكرار	عدد خطوات تكرار القوة
ε	الدقة المطلوبة	عادةً 10^{-8} في الأنظمة الحقيقية
c	مركزية المتجه الذاتي	أهمية العقدة i $c_i \propto$
$h,\ a$	متجهات HITS: المراكز (hubs) والسلطات (authorities)	متجهات ذاتية لـ $AA^\top$ و $A^\top A$

3.6.4 الشكل الهندسي



شكل ٦.٤: *
نظرية بيرون–فروبينيوس: المتجه الذاتي الموجب الوحيد هو توزيع PageRank المستقر

شكل 6.4 — على اليسار رسم ويب موجّه صغير مع «انتقال عشوائي» (teleport) احتماله $\alpha = 0.15$ يضمن أن المصفوفة موجبة بالكامل. على اليمين توزيع PageRank المستقر π: عمود أزرق لكل صفحة. التوزيع هو **المتجه الذاتي الوحيد الموجب** للقيمة الذاتية $\lambda = 1$، وهو ما تضمنه نظرية بيرون–فروبينيوس (39.4). وبما أن $|\lambda_2| \leq 1 - \alpha = 0.85$ فإن تكرار القوة يتقارب إليه بسرعة هندسية.

4.6.4 البرهان

برهان (39.4) — مخطّط (حالة $A>0$ موجبة قطعاً، ثم التعميم بالاستمرارية).

الخطوة 1 — الوجود. ليكن $\mathcal{K}=\{x\ge 0:\|x\|_1=1\}$ البسيطك (simplex)، وهو محدّب متراص. الخريطة $f(x)=\frac{Ax}{\|Ax\|_1}$ مستمرة وترسل $\mathcal{K}$ إلى نفسه (لأن $A\ge 0$). بنظرية براور للنقطة الثابتة يوجد $v\in\mathcal{K}$ مع $f(v)=v$ $\Longrightarrow$ $Av=\|Av\|_1\,v$ $\Longrightarrow$ قيمة ذاتية $\rho=\|Av\|_1>0$ بمتجه غير سالب.
الخطوة 2 — الإيجابية القطعية. إذا كان $A>0$ و $v\ge 0$ غير صفري فإن $Av>0$ $\Longrightarrow$ $v=Av/\rho>0$ ✓.
الخطوة 3 — البساطة. ليكن $Aw=\lambda w$ بـ $|\lambda|=\rho$. نأخذ القيمة المطلقة مكوّناً بمكوّن: $|Aw|\le A|w|$؛ وبضرب يساراً بمتجه بيرون الأيسر $u>0$ $(A^{\top}u=\rho u)$:

$$\rho\,u^{\top}|w|=u^{\top}A|w|\ge u^{\top}|Aw|=|\lambda|\,u^{\top}|w|=\rho\,u^{\top}|w|$$

فتتحقّق المساواة $\Longrightarrow$ $|Aw|=A|w|$ $\Longrightarrow$ لا إلغاء $\Longrightarrow$ w مكوّناته بنفس الطور $\Longrightarrow$ w مضاعف حقيقي موجب لـ v $\Longrightarrow$ $\lambda=\rho$ وبُعد الفضاء الذاتي 1 $\Longrightarrow$ **بسيطة**.
الخطوة 4 — التعميم على غير القابلة للاختزال. نأخذ $A_\varepsilon=A+\varepsilon\mathbf{1}\mathbf{1}^{\top}>0$ ونمرّر $\varepsilon\to 0$ بالاستمرارية (جذور كثيرة الحدود المميِّزة متصلة في المعاملات). وتفشل الإيجابية القطعية فقط في الحالة القابلة للاختزال. ■

برهان (40.4) — كولاتس-فيلانت.

ليكن $x>0$ و $\underline{\mu}=\min_i (Ax)_i/x_i$ و $\overline{\mu}=\max_i (Ax)_i/x_i$. بالتعريف: $\underline{\mu}\,x\le Ax\le\overline{\mu}\,x$ مكوّناً بمكوّن. نضرب يساراً بمتجه بيرون الأيسر $u>0$:

$$\underline{\mu}\,u^{\top}x\;\le\;u^{\top}Ax=\rho\,u^{\top}x\;\le\;\overline{\mu}\,u^{\top}x$$

وبما أن $u^{\top}x>0$ نقسم $\Longrightarrow$ $\underline{\mu}\le\rho\le\overline{\mu}$ ■

برهان (41.4)–(42.4).

الخطوة 1: G عشوائية صفّياً: كل صف مجموعه 1 $\Longrightarrow$ $G\mathbf{1}=\mathbf{1}$ $\Longrightarrow$ $\lambda=1$ قيمة ذاتية.
الخطوة 2: $G>0$ $\Longrightarrow$ $G_{ij}\ge\alpha/n>0$ **موجبة قطعاً** $\Longrightarrow$ بدائية $\Longrightarrow$ بـ (39.4) قيمة ذاتية بسيطة $\rho(G)=1$ بمتجه ذاتي **أيمن** موجب. وبما أن $G\mathbf{1}=\mathbf{1}$ فإن $\rho(G)=1$ (لأن نورم المشغّل اللانهاية $=1$). والمتجه الذاتي **الأيسر** الموجب π يحقّق $\pi G=\pi$، نوحّده بـ $\sum\pi_i=1$.
الخطوة 3 (حدّ $|\lambda_2|\le 1-\alpha$): نكتب $G=(1-\alpha)P+\alpha S$ حيث $S=\frac{1}{n}\mathbf{1}\mathbf{1}^{\top}$ إسقاط رتبة 1. لأي x مع $\mathbf{1}^{\top}x=0$ (أي $x\perp\mathbf{1}$): $Sx=0$ $\Longrightarrow$ $Gx=(1-\alpha)Px$ $\Longrightarrow$ $\|Gx\|_1\le(1-\alpha)\|x\|_1$. إذن تقييد G على $\{x:\mathbf{1}^{\top}x=0\}$ نورمه $\le 1-\alpha$ $\Longrightarrow$ كل قيمة ذاتية عدا 1 محصورة بـ $|\lambda|\le 1-\alpha$ ■

برهان (43.4).

نفكّك $\pi^{(0)} = \pi + z$ مع $\mathbf{1}^\top z = 0$. بالخطوة 3 أعلاه: zG^k ينكمش بعامل $(1-\alpha)^k \implies \|\pi^{(k)} - \pi\|_1 = \|zG^k\|_1 \le (1-\alpha)^k \|z\|_1 \le 2(1-\alpha)^k$ (لأن $\|z\|_1 \le \|\pi^{(0)}\|_1 + \|\pi\|_1 = 2$). ■

5.6.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (6.4-1): إيجاد نصف القطر الطيفي ومتجه بيرون

المعطيات: مصفوفة انتقال (غير معيارية) لشبكة:

$$A = \begin{bmatrix} 3 & 1 \\ 2 & 2 \end{bmatrix}$$

المطلوب: (أ) الطيف. (ب) $\rho(A)$ ومتجه بيرون. (ج) تحقّق من شروط النظرية.

الحل:

الخطوة 1 (التحقّق من الشروط): كل العناصر $> 0 \implies A$ موجبة قطعاً $\implies$ غير قابلة للاختزال وبدائية $\implies$ تنطبق (39.4) كاملة.

الخطوة 2 (الطيف): $p(\lambda) = (3-\lambda)(2-\lambda) - 2 = \lambda^2 - 5\lambda + 4 = (\lambda - 4)(\lambda - 1)$:

$$\lambda_1 = 4, \qquad \lambda_2 = 1$$

الخطوة 3: $\rho(A) = \max(|4|, |1|) = 4$ ✓ **وهو قيمة ذاتية حقيقية موجبة بسيطة.** ✓

الخطوة 4 (متجه بيرون): لـ $\lambda = 4$: $(3-4)v_1 + v_2 = 0 \implies v_2 = v_1 \implies v \propto (1,1)^\top$؛ بالتوحيد بـ $\|\cdot\|_1$:

$$v = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}, \qquad v_i > 0 \ \checkmark$$

الخطوة 5 (المتجه الآخر): لـ $\lambda = 1$: $2v_1 + v_2 = 0 \implies v \propto (1,-2)^\top$ — **ليس** موجباً ✓ متسق مع النظرية (المتجه الموجب وحيد).

الخطوة 6 (التحقّق من $|\lambda_2| < \rho$): $1 < 4$ ✓.

الخطوة 7 (التحقّق المباشر): $Av = \begin{pmatrix} 3\cdot 0.5 + 1\cdot 0.5 \\ 2\cdot 0.5 + 2\cdot 0.5 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix} = 4\begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}$ ✓.

النتيجة: $\rho(A) = 4$، $v = (0.5,\ 0.5)^\top$؛ $|\lambda_2| = 1 < 4 \implies$ تكرار القوة يتقارب بمعدّل 0.25^k.

الربط بالذكاء الاصطناعي: $\rho(A)$ **يحكم استقرار الشبكات الديناميكية:** إذا كانت $\rho(W_{\text{rec}}) > 1$ انفجر النظام تلاشى. ونظرية PF تضمن أن القيمة المهيمنة **حقيقية موجبة** $\implies$ لا تذبذب في الاتجاه المهيمن عندما تكون المصفوفة غير سالبة. (راجع المثال 10-2.4)، وإذا

مثال (6.4-2): تقييد $\rho(A)$ بكولاتس–فيلانت دون حساب القيم الذاتية

المعطيات: مصفوفة مجاورة لشبكة كبيرة (لا يمكن قطرنتها):

$$A = \begin{bmatrix} 3 & 1 \\ 2 & 2 \end{bmatrix}$$

المطلوب: حدّان على $\rho(A)$ من متجهي اختبار مختلفين.

الحل:

الخطوة 1 (اختبار أول $x^{(1)} = (1,\ 1.5)^\top$): $Ax^{(1)} = \binom{3+1.5}{2+3} = \binom{4.5}{5}$. النسب:

$$\frac{4.5}{1} = 4.5, \qquad \frac{5}{1.5} = 3.333$$

$$3.333 \ \le\ \rho(A)\ \le\ 4.5$$

الخطوة 2 (اختبار أفضل $x^{(2)} = (1,\ 1.1)^\top$): $Ax^{(2)} = \binom{3+1.1}{2+2.2} = \binom{4.1}{4.2}$. النسب:

$$\frac{4.1}{1} = 4.1, \qquad \frac{4.2}{1.1} = 3.818$$

$$3.818 \ \le\ \rho(A)\ \le\ 4.1$$

الخطوة 3 (التحقّق): القيمة الحقيقية $\rho = 4$ محصورة بين الحدّين ✓.

الخطوة 4 (الاختبار الأمثل): عند $x = v = (1,1)^\top$ تصبح النسب: $\frac{4}{1} = 4$ و $\frac{4}{1} = 4$ $\Longrightarrow$ الحدّان **يتطابقان** عند $\rho = 4$ ✓ (كما تنصّ النظرية: المساواة $\Longleftrightarrow$ x متجه بيرون).

الخطوة 5 (خوارزمية التحسين): بتطبيق (40.4) تكرارياً — نحدّث $x \ \leftarrow\ Ax/\|Ax\|$ — تتقلّص الفجوة بين الحدّين حتى تنعدم $\Longrightarrow$ هذه هي **خوارزمية تكرار القوة** مجدّداً، و (40.4) يعطي ضماناً على جودة التقدير في كل خطوة (ليس مجرّد حدس).

الخطوة 6 (تطبيق على مصفوفة 3×3): لو كانت $A = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix}$ و $x = (1,\ 1.4,\ 1)^\top$ فإن $Ax = (3.4,\ 4.8,\ 3.4)^\top$ والنسب: $3.4,\ 3.429,\ 3.4$ $\Longrightarrow$

$$3.400 \le \rho(A) \le 3.429$$

القيمة الحقيقية: $\lambda_k = 2 + 2\cos\frac{k\pi}{4}$ $\Longrightarrow$ $\rho = 2 + 2\cos(22.5^\circ) = 2 + 1.848 = 3.848$. **لا يقع في النطاق!** $\Longrightarrow$ خطأ: الحساب خاطئ. نراجع: Ax للعمود الأول: $2 \cdot 1 + 1 \cdot 1.4 + 0 \cdot 1 = 3.4$ ✓، الثاني: $1 + 1 \cdot 1 + 2 \cdot 1.4 + 1 \cdot 1 = 1 + 2.8 + 1 = 4.8$ ✓، الثالث: $0 + 1 \cdot 1.4 + 2 \cdot 1 = 3.4$ ✓. النسب: $3.4/1 = 3.4$، $4.8/1.4 = 3.4286$، $3.4/1 = 3.4$ $\Longrightarrow$ $\rho \in [3.4, 3.4286]$. لكن ρ الحقيقي $= 3.848$. **تناقض** $\Longrightarrow$ **خطأ في صيغة القيم الذاتية.** التصحيح: لهذه المصفوفة (ثلاثية القطر بـ $a = 2$، $b = 1$) الصيغة $\lambda_k = 2 + 2\cos\frac{k\pi}{n+1} = 2 + 2\cos\frac{k\pi}{4}$ بقيم $k = 1, 2, 3$: $k = 1$: $2 + 2(0.7071) = 3.4142$؛ $k = 2$: 2؛ $k = 3$: $2 - 1.4142 = 0.5858$. إذن $\rho = 3.4142$ وهو **داخل** النطاق $[3.4,\ 3.4286]$ ✓.

الخطوة 7 (استنتاج منهجي): كولاتس-فيلانت أداة **تحقّق وتشخيص** ممتازة: إن خرجت القيمة عن النطاق ففي الحساب خطأ.

النتيجة: $[3.818,\ 4.1]$ باختبار واحد، و $[3.4,\ 3.4286]$ للمصفوفة الثلاثية (الحقيقي 3.4142 ✓).

الربط بالذكاء الاصطناعي: هذه المتراجحة هي التي تجعل من الممكن **إصدار شهادات رياضية** على حدود النموّ في الشبكات العصبية المتكرّرة (مثلاً لإثبات أن النظام لن ينفجر) من دون حساب طيفي كامل.

مثال (4.6.3-3): بناء مصفوفة جوجل لشبكة صفحات صغيرة

المعطيات: 4 صفحات A, B, C, D بروابط: $A \to B$، $B \to C$، $C \to A$، $C \to D$، $D \to A$. معامل التخفيف $\alpha = 0.15$.

المطلوب: (أ) مصفوفة الانتقال P. (ب) مصفوفة جوجل G. (ج) تحقّق أن G عشوائية وموجبة.

الحل:

الخطوة 1 (الدرجات الخارجة): $d^{\text{out}}(A) = 1$، $d^{\text{out}}(B) = 1$، $d^{\text{out}}(C) = 2$، $d^{\text{out}}(D) = 1$.

الخطوة 2 (P عشوائية صفّياً): $P_{ij} = 1/d^{\text{out}}(i)$ إذا وُجد رابط $i \to j$:

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0.5 & 0 & 0 & 0.5 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

الخطوة 3 (التحقّق): مجاميع الصفوف: $1,\ 1,\ 1,\ 1$ ✓.

الخطوة 4 (مصفوفة الانتقال العشوائي): $\alpha \cdot \frac{1}{n}\mathbf{1}\mathbf{1}^\top = 0.15 \times 0.25 \cdot J = 0.0375\, J$ حيث J مصفوفة الواحدات.

الخطوة 5 (G بـ (41.4)): $G = 0.0375\, J + 0.85\, P$:

$$G = \begin{bmatrix} 0.0375 & 0.8875 & 0.0375 & 0.0375 \\ 0.0375 & 0.0375 & 0.8875 & 0.0375 \\ 0.4625 & 0.0375 & 0.0375 & 0.4625 \\ 0.8875 & 0.0375 & 0.0375 & 0.0375 \end{bmatrix}$$

(مثال: $G_{C,A} = 0.0375 + 0.85 \times 0.5 = 0.0375 + 0.425 = 0.4625$ ✓)

الخطوة 6 (التحقّق من كونها عشوائية): الصف الأول: $0.0375 + 0.8875 + 0.0375 + 0.0375 = 1.0$ ✓؛ الصف الثالث: $0.4625 + 0.0375 + 0.0375 + 0.4625 = 1.0$ ✓.

الخطوة 7 (التحقّق من الإيجابية القطعية): أصغر عنصر $0.0375 > 0$ ✓ $\Longrightarrow$ G موجبة قطعاً $\Longrightarrow$ **بدائية** $\Longrightarrow$ تنطبق PF $\Longrightarrow \pi > 0$ وحيد.

الخطوة 8 (لماذا نحتاج α؟) بدون التخفيف، المصفوفة P تحوي أصفاراً كثيرة وقد تكون قابلة للاختزال أو دورية $\Longrightarrow$ قد لا يوجد توزيع مستقر وحيد. التخفيف يجعل كل الصفحات متصلة $\Longrightarrow$ ضمان رياضي.

النتيجة: P و G كما أعلاه، G عشوائية صفّياً وموجبة قطعاً $\Longrightarrow$ PageRank وحيد وموجب.

الربط بالذكاء الاصطناعي: المصفوفة G تُبنى على شبكة ويب بمليارات العُقد، لكنها **متفرّقة** (كل صف فيه ≈ 10 عناصر غير صفرية من P زائد الكثيف J الذي يُعامل ضمنياً بالصيغة $\pi G = (1-\alpha)\pi P + \frac{\alpha}{n}\mathbf{1}^\top$) $\Longrightarrow$ كل تكرار يكلّف $O(|E|)$ فقط. هذه الصيغة («لا تكوّن G صريحاً») هي سرّ قابلية PageRank للتوسّع.

مثال (4.6.4-4): حساب PageRank بتكرار القوة

المعطيات: مصفوفة G من المثال السابق، والبداية $\pi^{(0)} = (0.25,\ 0.25,\ 0.25,\ 0.25)^\top$.

المطلوب: أربع تكرارات من $\pi^{(k+1)} = \pi^{(k)}G$ والتحقّق من حفظ المجموع.

الحل:

الخطوة 1 (التحديث كمتوسط مرجّح): بما أن $\pi^{(0)}$ منتظم فإن $\pi^{(1)}$ هو متوسط صفوف G (عمود بعمود):

$$\pi^{(1)}_A = \tfrac{1}{4}(0.0375 + 0.0375 + 0.4625 + 0.8875) = \tfrac{1.425}{4} = 0.35625$$

$$\pi^{(1)}_B = \tfrac{1}{4}(0.8875 + 0.0375 + 0.0375 + 0.0375) = \tfrac{1.0}{4} = 0.25$$

$$\pi_C^{(1)} = \tfrac{1}{4}(0.0375 + 0.8875 + 0.0375 + 0.0375) = 0.25$$

$$\pi_D^{(1)} = \tfrac{1}{4}(0.0375 + 0.0375 + 0.4625 + 0.0375) = \tfrac{0.575}{4} = 0.14375$$

$$\pi^{(1)} = (0.35625,\ 0.25,\ 0.25,\ 0.14375), \qquad \text{المجموع} = 1.0\ \checkmark$$

الخطوة 2 ($\pi^{(2)}$):

$$\pi_A^{(2)} = 0.35625(0.0375)+0.25(0.0375)+0.25(0.4625)+0.14375(0.8875) = 0.013359+0.009375+0.115625+$$

$$\pi_B^{(2)} = 0.35625(0.8875)+0.25(0.0375)+0.25(0.0375)+0.14375(0.0375) = 0.316172+0.009375+0.009375+$$

$$\pi_C^{(2)} = 0.35625(0.0375)+0.25(0.8875)+0.25(0.0375)+0.14375(0.0375) = 0.013359+0.221875+0.009375+$$

$$\pi_D^{(2)} = 0.35625(0.0375) + 0.25(0.0375) + 0.25(0.4625) + 0.14375(0.0375) = 0.143750$$

$$\pi^{(2)} = (0.265937,\ 0.340313,\ 0.250,\ 0.14375), \qquad \text{المجموع} = 1.0\ \checkmark$$

الخطوة 3 ($\pi^{(3)}$) — بنفس الطريقة:

$$\pi^{(3)} = (0.265938,\ 0.263547,\ 0.326767,\ 0.143751)$$

(تحقّق المجموع: $0.265938 + 0.263547 + 0.326767 + 0.143751 = 1.000003 \approx 1$ ✓)

الخطوة 4 ($\pi^{(4)}$):

$$\pi_A^{(4)} = 0.265938(0.0375) + 0.263547(0.0375) + 0.326767(0.4625) + 0.143751(0.8875)$$

$$= 0.009973 + 0.009883 + 0.151130 + 0.127579 = 0.298565$$

$$\pi_B^{(4)} = 0.265938(0.8875)+0.263547(0.0375)+0.326767(0.0375)+0.143751(0.0375) = 0.263548$$

$$\pi_C^{(4)} = 0.265938(0.0375)+0.263547(0.8875)+0.326767(0.0375)+0.143751(0.0375) = 0.261516$$

$$\pi_D^{(4)} = 0.265938(0.0375)+0.263547(0.0375)+0.326767(0.4625)+0.143751(0.0375) = 0.176377$$

$$\pi^{(4)} = (0.298565,\ 0.263548,\ 0.261516,\ 0.176377), \qquad \text{المجموع} = 1.000006 \approx 1\ \checkmark$$

الخطوة 5 (ملاحظة التذبذب): القيم تتذبذب بين التكرارات $(A : 0.356 \to 0.266 \to 0.266 \to 0.299)$ لأن الرسم شبه دوري، لكن هذا التذبذب يخمد بعامل 0.85^k.

الخطوة 6 (الترتيب الناشئ): $A > B \approx C > D$ — و A أعلى لأن الصفحتين C و D كلتاهما تشيران إليها ✓.

النتيجة: بعد 4 تكرارات: $\pi \approx (0.299,\ 0.264,\ 0.262,\ 0.176)$، الترتيب $A \succ B \approx C \succ D$.

الربط بالذكاء الاصطناعي: هذا بالضبط ما تفعله خوارزميات ترتيب العُقد (Personalized PageRank، TrustRank) في محركات البحث وأنظمة التوصية وتحليل الشبكات الاجتماعية. وصيغة «تكرار القوة على مصفوفة متفرّقة» هي نفسها صيغة تحديث التمثيلات في GNN.

مثال (4.6.5): عدد التكرارات اللازمة لتقارب PageRank

المعطيات: $\alpha = 0.15$ (قيمة جوجل الأصلية)، ومعيار التوقّف $\|\pi^{(k+1)} - \pi^{(k)}\|_1 < 10^{-6}$.

المطلوب: (أ) كم تكراراً نحتاج؟ (ب) كم لو استخدمنا $\alpha = 0.35$؟ (ج) المقايضة.

الحل:

الخطوة 1 (الحدّ النظري من (4.4.3)): $\|\pi^{(k)} - \pi\|_1 \le 2(1-\alpha)^k$؛ نطلب $2(0.85)^k \le 10^{-6}$:

$$k \;\ge\; \frac{\ln(10^{-6}/2)}{\ln 0.85} = \frac{\ln(5\times 10^{-7})}{-0.16252} = \frac{-14.5087}{-0.16252} = 89.3 \Longrightarrow k = 90 \text{ تكراراً}$$

الخطوة 2 (بمعيار 10^{-8} كما في الأنظمة الحقيقية): $k \ge \frac{\ln(5\times 10^{-9})}{-0.16252} = \frac{-19.1138}{-0.16252} = 117.6 \Longrightarrow 118$ تكراراً.

الخطوة 3 (بـ $\alpha = 0.35$): $\Longrightarrow 1-\alpha = 0.65$

$$k \ge \frac{-14.5087}{\ln 0.65} = \frac{-14.5087}{-0.43078} = 33.7 \Longrightarrow 34 \text{ تكراراً}$$

أي تسريع $\times 2.6$.

الخطوة 4 (المقايضة): رفع α يسرّع التقارب لكنه **يُفسد جودة الترتيب** لأنه يدفع التوزيع نحو المنتظم $\frac{1}{n}\mathbf{1}$:

$$\pi(\alpha) \;\longrightarrow\; \tfrac{1}{n}\mathbf{1} \quad \text{عند} \alpha \to 1$$

الخطوة 5 (قياس كمّي للتشويه): انتشار التوزيع (max − min) من المثال السابق: بـ $\alpha = 0.15$ بعد تكرار واحد $= 0.3125 - 0.1875 = 0.125$ (انظر المثال القادم) بـ $\alpha = 0.5$ $= 0.35625 - 0.14375 = 0.2125$ $\Longrightarrow$ انكماش 41% في التمييز بين الصفحات.

الخطوة 6 (الاختيار الأمثل): القيمة الشائعة $\alpha = 0.15$ توازن بين (أ) جودة الترتيب (الاعتماد على بنية الرسم) و (ب) سرعة التقارب و (ج) مقاومة «مزارع الروابط» (link farms).

الخطوة 7 (تسريع عملي): بدل رفع α نستخدم: (1) تكرارات كريلوف (GMRES/Lanczos) التي تتقارب أسرع من تكرار القوة، (2) التهيئة بتوزيع التكرار السابق (warm start) لأن الويب يتغيّر تدريجياً، (3) الحساب المتوازي على مجموعات العُقد.

النتيجة: 90 تكراراً بـ $\alpha = 0.15$ و $\varepsilon = 10^{-6}$، 34 تكراراً بـ $\alpha = 0.35$، المقايضة بين السرعة وجودة الترتيب.

الربط بالذكاء الاصطناعي: نفس المقايضة تظهر في GNN: زيادة «الانتقال العشوائي» (teleport) تسرّع الانتشار لكنها تدمج التمثيلات (oversmoothing). وفهمها عبر الطيف هو ما يجعل الضبط منهجياً لا تجريبياً.

مثال (4.6.6): مركزية المتجه الذاتي مقابل مركزية الدرجة

المعطيات: شبكة اجتماعية من 4 أشخاص بمصفوفة مجاورة (غير موجّهة):

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

المطلوب: (أ) مركزية المتجه الذاتي (بـ (4.4.4)). (ب) مركزية الدرجة. (ج) المقارنة.

الحل:

الخطوة 1 (استغلال التناظر): العقدتان 2 و 3 متماثلتان $\Longrightarrow c = (a,\ b,\ b,\ d)^\top$.

الخطوة 2: $Ac = \big(b+b+d,\ \ a+b,\ \ a+b,\ \ a\big)^\top = (2b+d,\ a+b,\ a+b,\ a)^\top = \lambda(a,\ b,\ b,\ d)^\top$.

الخطوة 3 (المعادلات): $2b + d = \lambda a$ (1)؛ $a + b = \lambda b$ (2)؛ $a = \lambda d$ (3).

الخطوة 4 (الاختزال): من (2): $a = b(\lambda - 1) \Longrightarrow b = \frac{a}{\lambda - 1}$. من (3): $d = \frac{a}{\lambda}$. نعوّض في (1):

$$\frac{2a}{\lambda - 1} + \frac{a}{\lambda} = \lambda a \implies \frac{2}{\lambda - 1} + \frac{1}{\lambda} = \lambda \implies 2\lambda + (\lambda - 1) = \lambda^2(\lambda - 1)$$

$$\lambda^3 - \lambda^2 - 3\lambda + 1 = 0$$

الخطوة 5 (الحلّ): نختبر: $\lambda = 2$: $8 - 4 - 6 + 1 = -1$؛ $\lambda = 2.2$: $10.648 - 4.84 - 6.6 + 1 = 0.208$؛ $\lambda = 2.17$: $\Longrightarrow 10.218 - 4.709 - 6.51 + 1 = -0.001$

$$\lambda_1 = 2.170 = \rho(A)$$

الخطوة 6 (المتجه): $b = \frac{a}{1.170} = 0.8547a$؛ $d = \frac{a}{2.170} = 0.4608a$. التوحيد الإقليدي: $a^2 + 2b^2 + d^2 = 1 \Longrightarrow a^2(1 + 1.4610 + 0.2123) = 2.6733a^2 = 1$:

$$a = 0.6116$$

$$c = (0.6116,\ 0.5228,\ 0.5228,\ 0.2818)^\top$$

الخطوة 7 (التحقّق): $Ac = (0.5228 + 0.5228 + 0.2818,\ 0.6116 + 0.5228,\ 0.6116 + 0.5228)^\top = (1.3274,\ 1.1344,\ 1.1344,\ 0.6116)^\top$ و $2.170\,c = (1.3272,\ 1.1345,\ 1.1345,\ 0.6115)^\top$؛ ✓.

الخطوة 8 (مركزية الدرجة): $d = (3,\ 2,\ 2,\ 1)$؛ بالتوحيد على الأكبر: $(1,\ 0.667,\ 0.667,\ 0.333)$.

الخطوة 9 (المقارنة): الترتيب متطابق: $1 \Longrightarrow 2 = 3 \succ 4$ لكن **النسب** مختلفة: $\frac{c_1}{c_4} = 2.17$ مقابل $\frac{d_1}{d_4} = 3$. مركزية المتجه الذاتي «أكثر اعتدالاً» لأنها لا تعاقب العقدة الطرفية بقدر ما تفعل مركزية الدرجة — فالعقدة 4 مرتبطة بالعقدة 1 (المهمة) وهذا يُحسب لها.

النتيجة: $c = (0.612,\ 0.523,\ 0.523,\ 0.282)$؛ $\rho = 2.170$؛ الترتيب متطابق مع مركزية الدرجة لكن النسب أقل تطرفاً.

الربط بالذكاء الاصطناعي: مركزية المتجه الذاتي تقف خلف خوارزميات ترتيب العُقد في GNN وتحليل الشبكات، وهي الصيغة الخطية التي تعمّمها «مركزية كاتز» (Katz centrality) و «العدد الثانوي للروابط». وهي أساس فكرة «التمثيلات البنيوية» (structural embeddings).

مثال (٤.٦-7): من العقدة الأكثر تأثيراً؟ ولماذا؟

المعطيات: مصفوفة جوجل من المثال 4.6-3 والترتيب النهائي $\pi \approx (A : 0.30,\ B : 0.26,\ C : 0.26,\ D : 0.18)$.

المطلوب: فسّر الترتيب بنيوياً، وتحقّق منه بمقياس «الروابط الداخلة».

الحل:

الخطوة 1 (الروابط الداخلة): A يستقبل من C و $D \Longrightarrow 2$؛ B من $A \Longrightarrow 1$؛ C من $B \Longrightarrow 1$؛ D من $C \Longrightarrow 1$.

الخطوة 2: الترتيب بالروابط الداخلة: $A \succ B = C = D \Longrightarrow A \succ B \approx C \succ D$ يعطي PageRank **متفق في القمّة** ✓ **ومختلف في الذيول.**

الخطوة 3 (لماذا $B = C = D$ وليس $B \approx C$؟) لأن C يستقبل من B **وزيادة** يمرّر نصف رتبته إلى $D \Longrightarrow C$ «محطة عبور» مهمة. في المقابل D يستقبل من C لكنه يمرّر كل رتبته إلى $A \Longrightarrow$ لا يحتفظ بشيء.

الخطوة 4 (التحليل بالمعادلة): من $\pi = (1 - \alpha)\pi P + \frac{\alpha}{n}\mathbf{1}^\top$:

$$\pi_A = 0.85\,(0.5\pi_C + 1.0\pi_D) + 0.0375$$

$$\pi_B = 0.85\,(1.0\pi_A) + 0.0375$$
$$\pi_C = 0.85\,(1.0\pi_B) + 0.0375$$
$$\pi_D = 0.85\,(0.5\pi_C) + 0.0375$$

الخطوة 5 (التحقّق بالقيم التقريبية): بـ $\pi \approx (0.30,\ 0.26,\ 0.26,\ 0.18)$: $\pi_B \approx 0.85(0.30) + 0.0375 = 0.2925$ (مقابل 0.2635 من التكرار — لم يتقارب بعد). نستمر في التكرار حتى الاستقرار.

الخطوة 6 (الاستنتاج): «الأهمية» في PageRank ليست عدد الروابط الداخلة فقط، بل **أهمية من يربط بك.** وهذا هو الفرق الجوهري عن المقاييس البسيطة، وهو ما يجعلها مقاومة للتلاعب الجزئي.

النتيجة: A الأكثر تأثيراً لأنها تستقبل من صفحتين إحداهما (C) عالية الترتيب وتمرّر رتبتها.

الربط بالذكاء الاصطناعي: نفس المنطق يُستخدم اليوم في: ترتيب النتائج في محرّكات البحث المتجهية (vector graph + search)، (reranking وتحديد «المؤثّرين» في التسويق الشبكي، واكتشاف العُقد الحرجة في شبكات الحواسيب للدفاع السيبراني.

مثال (6.4-8): أثر معامل التخفيف α على جودة الترتيب

المعطيات: نفس الرسم من المثال 6.4-3. نقارن $\alpha = 0.15$ و $\alpha = 0.5$.

المطلوب: (أ) احسب تكراراً واحداً لكلٍّ منهما. (ب) قارن «انتشار» التوزيع. (ج) أيهما تختار؟

الحل:

الخطوة 1 ($\alpha = 0.5$): $G = \frac{0.5}{4}J + 0.5P = 0.125\,J + 0.5\,P$:

$$G_{0.5} = \begin{bmatrix} 0.125 & 0.625 & 0.125 & 0.125 \\ 0.125 & 0.125 & 0.625 & 0.125 \\ 0.375 & 0.125 & 0.125 & 0.375 \\ 0.625 & 0.125 & 0.125 & 0.125 \end{bmatrix}$$

(مثال: $G_{C,A} = 0.125 + 0.5 \times 0.5 = 0.375$ ✓؛ مجاميع الصفوف $= 1$ ✓)

الخطوة 2 (تكرار واحد من التوزيع المنتظم):

$$\pi_A^{(1)} = \tfrac{1}{4}(0.125 + 0.125 + 0.375 + 0.625) = \tfrac{1.25}{4} = 0.3125$$

$$\pi_B^{(1)} = \tfrac{1}{4}(0.625{+}0.125{+}0.125{+}0.125) = 0.25, \qquad \pi_C^{(1)} = \tfrac{1}{4}(0.125{+}0.625{+}0.125{+}0.125) = 0.25$$

$$\pi_D^{(1)} = \tfrac{1}{4}(0.125 + 0.125 + 0.375 + 0.125) = \tfrac{0.75}{4} = 0.1875$$

الخطوة 3 ($\alpha = 0.15$ — من المثال 6.4-4): $\pi^{(1)} = (0.35625,\ 0.25,\ 0.25,\ 0.14375)$.

الخطوة 4 (الانتشار = max − min):

$$\alpha = 0.15:\ 0.35625 - 0.14375 = 0.2125, \qquad \alpha = 0.5:\ 0.3125 - 0.1875 = 0.125$$

الخطوة 5 (النتيجة): رفع α من 0.15 إلى 0.5 قلّص التمييز بين الصفحات بـ $41\% \Longrightarrow$ الترتيب أصبح أقرب إلى «الكل متساوٍ».

الخطوة 6 (التفسير الحدّي): عند $\alpha = 1$ يصبح $G = \frac{1}{n}J \Longrightarrow \pi = \frac{1}{n}\mathbf{1}$ (منتظم تماماً، بلا معلومة). وعند $\alpha = 0$ يصبح $G = P \Longrightarrow$ نعود إلى مشاكل الاختزال والدورية.

الخطوة 7 (الاختيار): $\alpha = 0.15$ هو توازن مجرَّب: تكفي لإيجابية G وضمان الوحودية والتقارب بـ $90 \approx$ تكراراً، مع احتفاظ الترتيب بـ 85% من بنية الرسم.

النتيجة: α أكبر $\Longrightarrow$ تقارب أسرع لكن تمييز أضعف، 0.15 هو التوازن المعتمد.

الربط بالذكاء الاصطناعي: نظير هذا المعامل في GNN هو وزن «الروابط الذاتية» (sefl-loop weight) وفي النماذج الانتشارية هو «جدول الضجيج». **في كل الحالات: مقدار الخلط مع التوزيع المنتظم يتحكّم في المقايضة بين الاستقرار والتمييز.**

مثال (4.6-9): مصفوفة قابلة للاختزال — عندما يفشل تكرار القوة

المعطيات: سلسلة صفحات «تمتصّ» الرتبة: $1 \to 2 \to 3 \to 3$ (العقدة 3 حوض absorbing).

$$P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix}$$

المطلوب: (أ) بيّن أن P قابلة للاختزال. (ب) ماذا يحدث لـ PageRank بلا تخفيف؟ (ج) كيف يحلّ التخفيف المشكلة؟

الحل:

الخطوة 1 (الاختزال): P مثلثية عليا $\Longrightarrow$ **قابلة للاختزال** (الرسم غير قوي الاتصال: لا يمكن العودة من 3 إلى 1 أو 2).

الخطوة 2 (الطيف): مثلثية $\Longrightarrow$ القيم الذاتية = عناصر القطر $(1,\ 0,\ 0) = \Longrightarrow \rho = 1$ (كما يجب لأي مصفوفة عشوائية).

الخطوة 3 (المتجه الذاتي الأيسر): نحلّ $\pi P = \pi$: $\pi_1 = 0$ (لا أحد يربط بـ 1)؛ $\pi_2 = \pi_1 \cdot 1 + 0 = 0$؛ $\Longrightarrow \pi_3 = \pi_2 + \pi_3 = \pi_3$

$$\pi = (0,\ 0,\ 1)$$

غير موجب $\Longrightarrow$ تنتهك (4.39) (التي تشترط عدم الاختزال) $\Longrightarrow$ **كل الرتبة تتركّز في العقدة 3.**

الخطوة 4 (المعنى): أي سائح عشوائي يقع في الحوض 3 ولا يخرج $\Longrightarrow$ كل «الأهمية» تذهب لصفحة واحدة $\Longrightarrow$ الترتيب بلا فائدة.

الخطوة 5 (الحل بالتخفيف): بـ $\alpha = 0.15$: $G = 0.05\,J + 0.85\,P$:

$$G = \begin{bmatrix} 0.05 & 0.90 & 0.05 \\ 0.05 & 0.05 & 0.90 \\ 0.05 & 0.05 & 0.90 \end{bmatrix}$$

الخطوة 6 (التوزيع المستقر الجديد): $\pi_2 = 0.90\pi_1 + \pi_1 = 0.05 \Longrightarrow \pi_1 = 0.05(\pi_1 + \pi_2 + \pi_3) = 0.05$
$\pi_3 = 1 - 0.05 - 0.0925 = 0.05\pi_2 + 0.05\pi_3 = 0.045 + 0.05(0.95) = 0.045 + 0.0475 = 0.0925$
0.8575

$$\pi = (0.05,\ 0.0925,\ 0.8575), \qquad \pi_i > 0\ \checkmark$$

الخطوة 7 (التحقّق): $\pi_3 = 0.05\pi_1 + 0.90\pi_2 + 0.90\pi_3 = 0.0025 + 0.08325 + 0.77175 = 0.85750$ ✓.

الخطوة 8 (الاستنتاج): التخفيف جعل G **موجبة قطعاً** $\Longrightarrow$ غير قابلة للاختزال وبدائية $\Longrightarrow$ ينطبق (4.39) $\Longrightarrow$ توزيع وحيد موجب. لاحظ أن العقدة 3 ما زالت الأعلى (0.8575) لكن بقي للعقدتين الأخريين نصيب $\Longrightarrow$ الترتيب صالح للاستخدام.

النتيجة: بلا تخفيف $\pi = (0, 0, 1)$ (انهيار)؛ بالتخفيف $\pi = (0.05,\ 0.0925,\ 0.8575)$ ✓.
الربط بالذكاء الاصطناعي: هذه الظاهرة تظهر في GNN على الرسوم ذات «المكوّنات المغلقة» وفي التعلّم المعزّز عندما تكون بعض الحالات نهائية (terminal states) $\Longrightarrow$ تُحَلّ بإعادة التشغيل العشوائي (ε-restarts) تماماً كما هنا.

مثال (6.4-10): العقد المعلّقة (dangling nodes) وتسريب الكتلة

المعطيات: نعدّل مثال 6.4-3 فنجعل الصفحة D بلا روابط خارجة (dangling).
المطلوب: (أ) بيّن مشكلة المصفوفة G. (ب) احسب الكتلة المفقودة في تكرار واحد. (ج) العلاج.
الحل:
الخطوة 1: صف D في P يصبح أصفاراً $\Longrightarrow$ صف D في G:

$$G_{D,:} = \frac{\alpha}{n}\mathbf{1}^\top + (1-\alpha)\cdot \mathbf{0}^\top = (0.0375,\ 0.0375,\ 0.0375,\ 0.0375)$$

مجموعه $1 \neq 0.15 = G \Longrightarrow$ **تحت-عشوائية** (sub-stochastic) $\Longrightarrow$ الكتلة تتسرّب.
الخطوة 2 (الكاملة):

$$G = \begin{bmatrix} 0.0375 & 0.8875 & 0.0375 & 0.0375 \\ 0.0375 & 0.0375 & 0.8875 & 0.0375 \\ 0.4625 & 0.0375 & 0.0375 & 0.4625 \\ 0.0375 & 0.0375 & 0.0375 & 0.0375 \end{bmatrix}$$

الخطوة 3 (تكرار واحد من المنتظم):

$$\pi_A^{(1)} = \tfrac{1}{4}(0.0375 + 0.0375 + 0.4625 + 0.0375) = \tfrac{0.575}{4} = 0.14375$$
$$\pi_B^{(1)} = \tfrac{1}{4}(0.8875 + 0.0375 + 0.0375 + 0.0375) = 0.25$$
$$\pi_C^{(1)} = \tfrac{1}{4}(0.0375 + 0.8875 + 0.0375 + 0.0375) = 0.25$$
$$\pi_D^{(1)} = \tfrac{1}{4}(0.0375 + 0.0375 + 0.4625 + 0.0375) = 0.14375$$

$$\text{المجموع} = 0.14375 + 0.25 + 0.25 + 0.14375 = 0.7875$$

الخطوة 4 (الكتلة المفقودة): $1 - 0.7875 = 0.2125$ أي 21.25%. وتفسيرها الدقيق: الكتلة التي كانت على D هي 0.25، و D «ينتقل عشوائياً» بنسبة $\alpha = 0.15$ فقط فيفقد $0.25 \times 0.85 = 0.25 \times (1 - 0.15) = 0.2125$ ✓ تطابق تام.
الخطوة 5 (الخطر): مع التكرار تتسرّب كل الكتلة $\Longrightarrow \pi^{(k)} \to 0 \Longrightarrow$ الخوارزمية تفشل تماماً.
الخطوة 6 (العلاج القياسي): استبدال صفوف العقد المعلّقة بالتوزيع المنتظم $\frac{1}{n}\mathbf{1}^\top$ (تفسير: السائح «ينتقل عشوائياً» حتماً إذا لم يجد رابطاً):

$$P_{D,:} \longleftarrow (0.25,\ 0.25,\ 0.25,\ 0.25)$$

$$G_{D,:} = 0.0375\,J + 0.85 \times 0.25\,J = (0.0375 + 0.2125)\,J = 0.25\,J \quad \text{مجموعه } 1 \checkmark$$

الخطوة 7 (بدائل أخرى): (أ) حذف العقد المعلّقة (تكرارياً حتى الاستقرار)؛ (ب) توجيهها إلى «عقدة صندوق» (sink node) تُعامل كعقدة معلّقة بدورها؛ (ج) استخدام $\alpha = 1$ على صفوفها فقط.

الخطوة 8 (التحقّق بعد العلاج): مجاميع كل صفوف G = 1 $\Longrightarrow$ التكرار يحفظ الكتلة $\Longrightarrow$ التقارب مضمون بـ (42.4).

النتيجة: الكتلة المفقودة 21.25% = في تكرار واحد، العلاج باستبدال صفوف العقد المعلّقة بالمنتظم $\Longrightarrow$ G عشوائية تماماً.

الربط بالذكاء الاصطناعي: نظير هذه المشكلة في GNN هو العُقد المعزولة (isolated nodes) التي تُسبّب أصفاراً في القطر وتفشل تطبيع $D^{-1/2}$ $\Longrightarrow$ العلاج المعتاد إضافة روابط ذاتية (sefl-loops) وهو تماماً نظير «الانتقال العشوائي».

مثال (11-6.4): ترتيب العناصر في نظام توصية بسير عشوائي على رسم العناصر

المعطيات: 3 عناصر وتفاعلات: $u_1 : \{i_1, i_2\}$، $u_2 : \{i_1, i_2, i_3\}$، $u_3 : \{i_1\}$.

المطلوب: (أ) ابنِ رسم العناصر من التلازم. (ب) احسب التوزيع المستقر. (ج) أوصِ لمستخدم استهلك i_1.

الحل:

الخطوة 1 (مصفوفة التلازم): عدد المستخدمين الذين تفاعلوا مع الزوج:

$$w_{12} = |\{u_1, u_2\}| = 2, \qquad w_{13} = |\{u_2\}| = 1, \qquad w_{23} = |\{u_2\}| = 1$$

$$W = \begin{bmatrix} 0 & 2 & 1 \\ 2 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

الخطوة 2 (مصفوفة الانتقال): بتطبيع الصفوف (الدرجات 2 ,3 ,3):

$$P = \begin{bmatrix} 0 & 2/3 & 1/3 \\ 2/3 & 0 & 1/3 \\ 1/2 & 1/2 & 0 \end{bmatrix}$$

الخطوة 3 (التوزيع المستقر): نحلّ $\pi = \pi P$. بالتناظر بين 1 و 2: $\pi_1 = \pi_2$: $\pi_1 = \frac{2}{3}\pi_2 + \frac{1}{2}\pi_3 = \frac{2}{3}\pi_1 + \frac{1}{2}\pi_3$ $\Longrightarrow$ $\frac{1}{3}\pi_1 = \frac{1}{2}\pi_3$ $\Longrightarrow$ $\pi_1 = \frac{3}{2}\pi_3$ $\pi_3 = \frac{1}{3}\pi_1 + \frac{1}{3}\pi_2 = \frac{2}{3}\pi_1$ ✓ متسق (لأن $\pi_1 = 1.5\pi_3 \Longleftrightarrow \pi_3 = \frac{2}{3}\pi_1$) التوحيد: $1 = \pi_1 + \pi_2 + \pi_3 = 2\pi_1 + \frac{2}{3}\pi_1 = \frac{8}{3}\pi_1$ $\Longrightarrow$ $\pi_1 = \frac{3}{8} = 0.375$:

$$\pi = (0.375,\ 0.375,\ 0.250)$$

الخطوة 4 (التخصيص الشخصي — PageRank Personalized من i_1): بـ $\alpha = 0.15$: $G = 0.05\, J + 0.85\, P$:

$$\text{صف} i_1 = (0.05,\ 0.05 + 0.85 \cdot \tfrac{2}{3},\ 0.05 + 0.85 \cdot \tfrac{1}{3}) = (0.05,\ 0.6167,\ 0.3333)$$

$$\text{صف} i_2 = (0.6167,\ 0.05,\ 0.3333), \qquad \text{صف} i_3 = (0.475,\ 0.475,\ 0.05)$$

من $\pi^{(0)} = (1, 0, 0)$: $\pi^{(1)} = (0.05,\ 0.6167,\ 0.3333)$؛ ثم:

$$\pi_1^{(2)} = 0.05(0.05) + 0.6167(0.6167) + 0.3333(0.475) = 0.0025 + 0.3803 + 0.1583 = 0.5411$$

$$\pi_2^{(2)} = 0.05(0.6167) + 0.6167(0.05) + 0.3333(0.475) = 0.0308 + 0.0308 + 0.1583 = 0.2199$$

$$\pi_3^{(2)} = 0.05(0.3333) + 0.6167(0.3333) + 0.3333(0.05) = 0.0167 + 0.2056 + 0.0167 = 0.2390$$

الخطوة 5 (التوصية): للمستخدم الذي استهلك i_1: نرتب العناصر المتبقية بالدرجة الشخصية: $i_3\ (0.239) > i_2\ (0.220)$ عند التكرار الثاني؛ ومع التقارب إلى التوزيع المستقر يصبح $i_3\ (0.250) < i_2\ (0.375)$.

الخطوة 6 (القرار): التوصية المستقرّة: i_2 (أعلى درجة بعد استبعاد المستهلَك). والدرجة «الشخصية» قصيرة المدى تعطي انطباعاً مختلفاً $\Longrightarrow$ تُستخدم عادةً بعد 5–10 تكرارات لتوازن الخصوصية والعمومية.

الخطوة 7 (الميزة على التصفية التعاونية البسيطة): السير العشوائي يلتقط علاقات **غير مباشرة**: $i_1 \to i_2 \to i_3$ يكشف عناصر لم تظهر معاً قط.

النتيجة: رسم العناصر W؛ التوزيع المستقر $(0.375,\ 0.375,\ 0.25)$؛ التوصية i_2.

الربط بالذكاء الاصطناعي: هذه هي خوارزمية **PageRank Personalized / ItemRank** التي تستخدمها أنظمة التوصية الصناعية (وخوارزمية Pixie في Pinterest على مئات الملايين من العُقد). والصيغة الحديثة تغلّفها شبكات عصبية بيانية، GraphSAGE) .(PinSage

مثال (12-6.4): خوارزمية HITS — المراكز والسلطات

المعطيات: رسم موجّه بـ 3 عُقد: $2 \to 1$، $3 \to 1$، $3 \to 2$، $1 \to 3$.

$$A = \begin{bmatrix} 0 & 1 & 1 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

المطلوب: (أ) درجات المراكز (hubs). (ب) درجات السلطات (authorities). (ج) التفسير.

الحل:

الخطوة 1 (العلاقة بـ (44.4)): $h = Aa$ و $a = A^\top h \Longrightarrow h = AA^\top h$ و $a = A^\top A\, a \Longrightarrow$ كلٌّ منهما متجه ذاتي لمصفوفة متماثلة نصف موجبة $\Longrightarrow$ تنطبق PF (بعد التأكد من عدم الاختزال).

الخطوة 2 ($AA^\top$):

$$AA^\top = \begin{bmatrix} 0+1+1 & 0+0+1 & 0+0+0 \\ 0+0+1 & 0+0+1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

الخطوة 3 (القيم الذاتية): الكتلة $\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$: الأثر 3، المحدّد $2-1=1 \Longrightarrow \lambda^2-3\lambda+1=0 \Longrightarrow \lambda = \frac{3\pm\sqrt{5}}{2} = 2.618,\ 0.382$. والعنصر المنفصل $(3,3)$ يعطي 1. القيمة المهيمنة:

$$\lambda_1(AA^\top) = 2.618$$

الخطوة 4 (متجه المراكز): $(2-2.618)v_1 + v_2 = 0 \Longrightarrow v_2 = 0.618\, v_1$، والثالث 0:

$$h \propto (1,\ 0.618,\ 0) \xrightarrow{\text{توحيد}} h = (0.8507,\ 0.5257,\ 0)^\top$$

الخطوة 5 ($A^\top A$):

$$A^\top A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

(الأعمدة: $c_1 = (0,0,1)^\top$، $c_2 = (1,0,0)^\top$، $c_2^\top c_3 = 1 \Longrightarrow c_3 = (1,1,0)^\top$، ✓ $c_3^\top c_3 = 2$)

الخطوة 6 (متجه السلطات): الكتلة السفلية $\begin{bmatrix}1 & 1\\ 1 & 2\end{bmatrix}$ لها نفس القيم $(2.618,\ 0.382)$؛ $(1-2.618)v_2+v_3=0 \Rightarrow v_3 = 1.618\,v_2$:

$$a = (0,\ 0.5257,\ 0.8507)^\top$$

الخطوة 7 (التحقّق): $A^\top h = \begin{bmatrix}0&0&1\\1&0&0\\1&1&0\end{bmatrix}\begin{bmatrix}0.8507\\0.5257\\0\end{bmatrix} = \begin{bmatrix}0\\0.8507\\1.3764\end{bmatrix}$؛ ولو قسّمنا على $\sqrt{\lambda_1}=\sqrt{2.618}=1.618$: $a = (0,\ 0.5257,\ 0.8507)^\top$ ✓.

الخطوة 8 (التفسير): العقدة 1 أفضل **مركز** (hub) لأنها تربط بـ 2 و 3، والعقدة 3 أفضل **سلطة** (authority) لأنها تستقبل من 1 و 2. والعقدة 2 وسط بينهما.

النتيجة: $h=(0.851,\ 0.526,\ 0)$؛ $a=(0,\ 0.526,\ 0.851)$؛ $\lambda_1 = 2.618$.

الربط بالذكاء الاصطناعي: Kleinberg HITS) 1999) سبقت PageRank وتُستخدم حتى اليوم في تحليل الويب والاستشهادات الأكاديمية. وصيغتها الحديثة (القيم الذاتية لـ $A^\top A$ و $AA^\top$) هي نفسها **SVD** للمصفوفة A — فـ h_i و a_i هما المتجهات المفردة اليسرى واليمنى! (راجع (17.4)).

مثال (13-6.4): سلسلة ماركوف — التوزيع المستقر وزمن الاختلاط

المعطيات: سلسلة ماركوف بحالتين (مثلاً «نشط/خامل» لمستخدم في تطبيق):

$$P = \begin{bmatrix}0.9 & 0.1\\ 0.2 & 0.8\end{bmatrix}$$

المطلوب: (أ) التوزيع المستقر. (ب) زمن الاختلاط بدقة 1%. (ج) تحقّق.

الحل:

الخطوة 1: نحلّ $\pi P = \pi$ مع $\pi_1+\pi_2=1$:

$$\pi_1 = 0.9\pi_1 + 0.2\pi_2 \implies 0.1\pi_1 = 0.2\pi_2 \implies \pi_1 = 2\pi_2$$

$$\pi = \left(\tfrac{2}{3},\ \tfrac{1}{3}\right) = (0.6667,\ 0.3333)$$

الخطوة 2 (القيم الذاتية): الأثر $=1.7$؛ المحدّد $=0.72-0.02=0.70 \Rightarrow \lambda_1=1$ (دائماً للمصفوفة العشوائية) و $\lambda_2 = 0.7$.

الخطوة 3 (فجوة الطيف): $1-|\lambda_2| = 0.3 \Rightarrow$ معدّل التقارب $=0.7^k$.

الخطوة 4 (زمن الاختلاط): نطلب $0.7^k \le 0.01$:

$$k \ge \frac{\ln 0.01}{\ln 0.7} = \frac{-4.6052}{-0.35667} = 12.91 \Rightarrow k = 13 \text{ خطوة}$$

الخطوة 5 (التحقّق العددي): من $\pi^{(0)}=(1,\ 0)$: نحسب تكرارياً — P^{13}: $\pi^{(1)}=(0.9,\ 0.1)$؛ $\pi^{(2)}=(0.9\cdot$؛ $\pi^{(3)} = (0.83\cdot 0.9+0.17\cdot 0.2,\ 0.83\cdot 0.1+0.9+0.1\cdot 0.2,\ 0.9\cdot 0.1+0.1\cdot 0.8) = (0.83,\ 0.17)$؛ $(0.17\cdot 0.8) = (0.747+0.034,\ 0.083+0.136) = (0.781,\ 0.219)$؛ الخطأ $|\pi_1^{(3)}-0.6667| = 0.1143$؛ والتنبؤ $0.7^3 = 0.343$ من خطأ ابتدائي $0.3333 \Rightarrow 0.3333\times 0.343 = 0.1143$ ✓ **تطابق تام.** وبـ $k=13$: $0.3333\times 0.7^{13} = 0.3333\times 0.00969 = 0.00323 < 0.01$ ✓.

الخطوة 6 (التفسير): بعد $13\approx$ خطوة ينسى النظام حالته الابتدائية $\Rightarrow$ أي توقّع طويل الأمد يعتمد على π فقط.

الخطوة 7 (العلاقة بـ PageRank): PageRank حالة خاصة: α يضمن $|\lambda_2| \le 1-\alpha \implies$ زمن اختلاط $\approx \frac{\ln \varepsilon}{\ln(1-\alpha)}$ — وهو بالضبط المثال 6.4-5.

النتيجة: $\pi = (2/3,\ 1/3)$، $|\lambda_2| = 0.7$؛ زمن الاختلاط $= 13$ خطوة.

الربط بالذكاء الاصطناعي: كل نموذج تسلسلي (HMM، سلاسل ماركوف، عمليات اتخاذ القرار الماركوفية MDP في التعلّم المعزّز) يعتمد على هذا التحليل: $|\lambda_2|$ يحدّد «ذاكرة» النظام ومدى اعتماده على الحالة الابتدائية. وفي RL، الفجوة الطيفية تحدّد سرعة تقييم السياسات.

مثال (6.4-14): كشف «مزرعة روابط» طيفياً

المعطيات: رسم من 4 صفحات: $\{1,2\}$ دورة مغلقة و $\{3,4\}$ دورة مغلقة، ولا روابط بينهما (هذه بنية «مزرعة روابط» كلاسيكية):

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

المطلوب: (أ) الطيف وماذا يدلّ؟ (ب) التوزيعات المستقرة. (ج) كيف نكشف المزرعة؟

الحل:

الخطوة 1 (البنية): P قطرية الكتل $\implies$ **قابلة للاختزال** $\implies$ تنتهك شروط (39.4).

الخطوة 2 (الطيف): طيف كل كتلة $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ هو $\{1,\ -1\} \implies$

$$\lambda(P) = (1,\ 1,\ -1,\ -1)$$

الخطوة 3 (التشخيص): تكرار القيمة الذاتية 1 مرّتين $\implies$ **مكوّنان مغلقان** $\implies$ كل منهما «يحتفظ» برتبته ولا يتقاسمها مع الآخر $\implies$ علامة تلاعب.

الخطوة 4 (التوزيعات المستقرة): فضاء المتجهات الذاتية اليسرى لـ 1 $=$ λ بُعده 2 $\implies$ أي مزيج $t(\frac{1}{2},\frac{1}{2},0,0) + (1-t)(0,0,\frac{1}{2},\frac{1}{2})$ $=$ π توزيع مستقر $\implies$ **غير وحيد** $\implies$ PageRank بلا تخفيف غير صالح.

الخطوة 5 (الحل بالتخفيف): بـ $\alpha = 0.15$: $G = 0.0375\,J + 0.85\,P$:

$$G = \begin{bmatrix} 0.0375 & 0.8875 & 0.0375 & 0.0375 \\ 0.8875 & 0.0375 & 0.0375 & 0.0375 \\ 0.0375 & 0.0375 & 0.0375 & 0.8875 \\ 0.0375 & 0.0375 & 0.8875 & 0.0375 \end{bmatrix}$$

موجبة قطعاً $\implies$ وحيدة، وبالتناظر $\pi = (\frac{1}{4},\frac{1}{4},\frac{1}{4},\frac{1}{4})$ المنتظم $\implies$ **لا تمييز** $\implies$ المزرعة لم تستفد.

الخطوة 6 (كيف نكشفها؟) ثلاث علامات طيفية:

١. **تكرار القيمة الذاتية 1** في P (أو في مصفوفة المجاورة المطبَّعة) $\implies$ مكوّنات مغلقة.

٢. **الفجوة الطيفية شبه معدومة** بين λ_1 و $\lambda_2 \implies$ المتجه الذاتي الثاني «متمركز» على مجموعة صغيرة $\implies$ هذا هو كاشف العناقيد/المزارع.

٣. **الموصلية (conductance) شبه صفرية** لمجموعة العُقد $\implies$ العلاج: حساب «الموصلية الطيفية» لكل عنقود مرشّح ورفض العناقيد ذات الموصلية $< \varepsilon$.

الخطوة 7 (القياس الكمّي): لو كانت المزرعة متصلة بالويب الخارجي برابط واحد فقط، فإن $\varepsilon \approx 1 - \lambda_2$ مع $\varepsilon \propto$ وزن الرابط الخارجي $\Longrightarrow$ كلما صغر الرابط الخارجي اقترب λ_2 من 1 $\Longrightarrow$ كشف مباشر.

النتيجة: $\lambda(P) = (1, 1, -1, -1)$ $\Longrightarrow$ مكوّنان مغلقان $\Longrightarrow$ توزيع غير وحيد $\Longrightarrow$ علامة تلاعب؛ التخفيف يجعل الحلّ وحيداً منتظماً.

الربط بالذكاء الاصطناعي: هذا هو الأساس الطيفي لكشف الاحتيال (fraud detection) والروابط المزيفة ومزارع المتابعين: **المجتمعات المغلقة طيفياً علامة خطر.** والطريقة الحديثة تعمّمها عبر «الموصلية الطيفية» و «الطيف المحلي» (local spectral methods).

مثال (15-6.4): ترتيب الأوراق البحثية في شبكة اقتباسات

المعطيات: 5 أوراق، الاقتباسات: $P_1 \to \{P_2, P_3\}$، $P_2 \to \{P_3\}$، $P_3 \to \{P_5\}$، $P_4 \to \{P_3\}$، P_5 لا تستشهد شيئاً (عقدة معلّقة). $\alpha = 0.15$.

المطلوب: (أ) مصفوفة الانتقال بعد معالجة العقدة المعلّقة. (ب) تكراران من PageRank. (ج) الترتيب.

الحل:

الخطوة 1 (الدرجات الخارجة): $P_5 \Longrightarrow 2,\ 1,\ 1,\ 1,\ 0$ معلّقة.

الخطوة 2 (المعالجة): صف $P_5 \longleftarrow$ منتظم $(0.2,\ 0.2,\ 0.2,\ 0.2,\ 0.2)$.

الخطوة 3 (P): $P_{1,:} = (0,\ 0.5,\ 0.5,\ 0,\ 0)$؛ $P_{2,:} = (0, 0, 1, 0, 0)$؛ $P_{3,:} = (0, 0, 0, 0, 1)$؛ $P_{4,:} = (0, 0, 1, 0, 0)$؛ $P_{5,:} = 0.2\,J$.

الخطوة 4 ($G = 0.03\,J + 0.85\,P$):

$$G = \begin{bmatrix} 0.03 & 0.455 & 0.455 & 0.03 & 0.03 \\ 0.03 & 0.03 & 0.88 & 0.03 & 0.03 \\ 0.03 & 0.03 & 0.03 & 0.03 & 0.88 \\ 0.03 & 0.03 & 0.88 & 0.03 & 0.03 \\ 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \end{bmatrix}$$

(الصف الخامس: $0.03 + 0.85 \times 0.2 = 0.2$ ✓ ومجموعه 1 ✓)

الخطوة 5 (تكرار أول من المنتظم — متوسط الأعمدة):

$$\pi^{(1)} = \big(0.064,\ 0.149,\ 0.489,\ 0.064,\ 0.234\big)$$

(تحقّق العمود الثالث: $\frac{1}{5}(0.455 + 0.88 + 0.03 + 0.88 + 0.2) = \frac{2.445}{5} = 0.489$ ✓؛ المجموع $= 1.0$ ✓)

الخطوة 6 (تكرار ثانٍ):

$$\pi_1^{(2)} = 0.064(0.03)+0.149(0.03)+0.489(0.03)+0.064(0.03)+0.234(0.2) = 0.00192+0.00447+0.01467+0.0$$

$$\pi_2^{(2)} = 0.064(0.455)+0.149(0.03)+0.489(0.03)+0.064(0.03)+0.234(0.2) = 0.02912+0.00447+0.01467+0.$$

$$\pi_3^{(2)} = 0.064(0.455)+0.149(0.88)+0.489(0.03)+0.064(0.88)+0.234(0.2) = 0.02912+0.13112+0.01467+0.$$

$$\pi_4^{(2)} = 0.06978 \text{ (بالتماثل مع 1)}, \qquad \pi_5^{(2)} = 0.064(0.03)+0.149(0.03)+0.489(0.88)+0.064(0.03)+0.234(0.2) =$$

$$\pi^{(2)} = (0.0698,\ 0.0970,\ 0.2780,\ 0.0698,\ 0.4854), \quad \text{المجموع} = 1.0\ \checkmark$$

الخطوة 7 (الترتيب): $P_5 \succ P_3 \succ P_2 \succ P_1 = P_4$.

الخطوة 8 (التفسير النقدي): P_5 في القمّة لأنها تستقبل من P_3 ولا تمرّر رتبتها لأحد (بسبب معالجة العقدة المعلّقة) $\Longrightarrow$ هذا **أثر اصطناعي** لمعالجة العقد المعلّقة. العلاجات: (أ) حذف العقد المعلّقة قبل الحساب؛ (ب) استخدام معامل تخفيف أعلى؛ (ج) وزن الاقتباسات بعمر الورقة (time-decayed PageRank) لأن الأوراق الحديثة لم تتح لها فرصة الاستشهاد.

النتيجة: $\pi^{(2)} = (0.070,\ 0.097,\ 0.278,\ 0.070,\ 0.485)$؛ الترتيب $P_5 \succ P_3 \succ P_2 \succ P_1 = P_4$، مع تحذير من الأثر الاصطناعي.

الربط بالذكاء الاصطناعي: ترتيب الأوراق العلمية (وبراءات الاختراع والمحاكم القضائية) يعتمد على هذه التقنية مع تحسينات زمنية. والدرس المنهجي المهم: **كل «إصلاح» رياضي (مثل معالجة العقد المعلّقة) يُدخل تحيّزاً يجب تقييمه** — وهذا درس عام في هندسة الخوارزميات.

6.6.4 أخطاء شائعة في بيرون–فروبينيوس و PageRank

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	افتراض أن المتجه الذاتي المهيمن موجب لأي مصفوفة	يشترط عدم السلبية وعدم الاختزال	تحقّق من شروط (39.4)
2	الخلط بين المتجه الذاتي الأيمن والأيسر	في PageRank المطلوب هو الأيسر ($\pi G = \pi$)	P عشوائية صفّياً $\Longrightarrow$ π أيسر
3	ترك العقد المعلّقة بصفوف أصفار	الكتلة تتسرّب $\pi \to 0 \Longrightarrow$	استبدل صفوفها بالمنتظم (المثال 6.4-10)
4	الاعتقاد أن $\rho(A) \le \max_i \sum_j A_{ij}$ دائماً	صحيح فقط لـ $A \ge 0$	للمصفوفات غير السالبة: نعم (نورم اللانهاية)
5	استخدام $\alpha = 0$ لتوفير الحساب	قد تفشل الوحودية والتقارب	احتفظ بـ $\alpha \ge 0.05$
6	توقّع تقارب أسرع من $(1-\alpha)^k$	هذا هو الحدّ الأقصى المضمون	$\lvert\lambda_2\rvert \le 1-\alpha$ (42.4)، وقد يكون أفضل
7	تطبيع A صفّياً عندما الروابط «واردة»	الاتجاه يحدّد نوع التطبيع	π أيسر $\Longrightarrow$ صفوف، c أيمن $\Longrightarrow$ أعمدة
8	تفسير $\lvert\lambda_2\rvert$ الكبير على أنه جيد دائماً	كبير $\Longrightarrow$ بطء التقارب وضعف الاتصال	في الترتيب نريد صغيراً، في التوسّع نريد كبيراً
9	تجاهل أن G كثيفة (بسبب J)	تخزينها $O(n^2)$	استخدم $\pi G = (1-\alpha)\pi P + \frac{\alpha}{n}\mathbf{1}^\top$ ضمنياً
10	الخلط بين PageRank ومركزية المتجه الذاتي	الأولى بمعامل تخفيف والأخرى بدونه	PageRank = مركزية مُخفَّفة (damped)

المجموعة أ — التحليل الطيفي ودوال المصفوفات (1–6)

تمرين 1. احسب القيم والمتجهات الذاتية لـ $A = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}$ وتحقّق من (4.4).

تمرين 2. ليكن $A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$. بيّن أنها غير قابلة للقطرنة وعلّق على ذلك.

تمرين 3. احسب A^5 لـ $A = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ بطريقتين: القطرنة، وكايلي–هاملتون.

تمرين 4. احسب e^{At} ثم حلّ $\dot{x} = Ax$ مع $x(0) = (1, 0)^\top$ حيث $A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$.

تمرين 5. احسب $\Sigma^{1/2}$ و $\Sigma^{-1/2}$ لـ $\Sigma = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ وتحقّق أن $(\Sigma^{1/2})^2 = \Sigma$.

تمرين 6. بيّن أن كل مصفوفة متماثلة موجبة التحديد لها جذر تربيعي متماثل موجب التحديد وحيد.

إجابات مختصرة (أ): (1) $\lambda = 6, 2$؛ $q_1 = \frac{1}{\sqrt{2}}(1,1)^\top$، $q_2 = \frac{1}{\sqrt{2}}(1,-1)^\top$. (2) $\lambda = 1$ بتكرار جبري 2 وهندسي 1 $\Longrightarrow$ defective. (3) $A^5 = \frac{1}{2}\begin{bmatrix} 3^5+(-1)^5 & 3^5-(-1)^5 \\ 3^5-(-1)^5 & 3^5+(-1)^5 \end{bmatrix} = \begin{bmatrix} 121 & 122 \\ 122 & 121 \end{bmatrix}$. (4) $x(t) = (\cosh t,\ \sinh t)^\top$. (5) $\Sigma^{1/2} = \frac{1}{\sqrt{2}}\begin{bmatrix} \sqrt{3}+1 & \sqrt{3}-1 \\ \sqrt{3}-1 & \sqrt{3}+1 \end{bmatrix} \cdot \frac{1}{2}$. (6) $Q = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$. الدقّة: $\Sigma^{1/2} = Q\,\mathrm{diag}(\sqrt{3}, 1)Q^\top$ ... $f(\lambda) = \sqrt{\lambda}$ بـ (11.4) من

والوحودية من بساطة التحليل الطيفي عند تكرار القيم الذاتية المتساوي.

المجموعة ب — SVD والتقريب من رتبة منخفضة (7–12)

تمرين 7. احسب SVD الكامل لـ $A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ (غير متماثلة!).

تمرين 8. احسب أفضل تقريب برتبة 1 لـ $A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$ والخطأ بالنورمين.

تمرين 9. بيّن أن $\|A\|_2 = \sigma_1$ و $\|A\|_F^2 = \sum \sigma_i^2$ بالاعتماد على (18.4).

تمرين 10. احسب المعكوس الشمولي $A^\dagger$ لـ $A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$ (شاذّة!) وتحقّق من شروط مور–بنروز.

تمرين 11. مصفوفة 50×50 بقيم مفردة $\sigma_i = 100/i$. كم الرتبة اللازمة لـ 99% من الطاقة؟ (استخدم تقريباً تكاملياً.)

تمرين 12. بيّن أن $\operatorname{rank}(A) = \operatorname{rank}(A^\top A)$ مستخدماً $\ker(A^\top A) = \ker(A)$.

إجابات مختصرة (ب): (7) $\sigma = (\frac{1+\sqrt{5}}{2}, \frac{\sqrt{5}-1}{2}) \approx (1.618,\ 0.618)$، $U \neq V$. (8) $A_1 = 2\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$؛ الخطأ الطيفي $= \sigma_2 = 2$ والفروبينيوس $= 2$. (10) $A^\dagger = \frac{1}{25}\begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$. (11) $\sum_i \sigma_i^2 = 10^4 \sum i^{-2} \approx 10^4 \cdot \frac{\pi^2}{6} = 16449$؛ الذيول $\sum_{i>k} \frac{10^4}{i^2} \approx \frac{10^4}{k}$ $\Longrightarrow$ نطلب $\frac{10^4/k}{16449} \leq 0.01 \Longrightarrow k \geq 61 \Longrightarrow k \approx 61$ (أو نحتفظ بكل الرتبة لأن k قريب من 50 $\Longrightarrow$ عملياً $k \approx 50$). (12) مباشرة من البرهان في §4.3.4.

المجموعة ج — رايلي وفايل والتداخل (13–18)

تمرين 13. احسب خارج قسمة رايلي لـ $A = \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix}$ عند $x = (1, 2)^\top$ وقارن بالقيم الذاتية.

تمرين 14. ليكن E بـ $\|E\|_2 = 0.1$. احسب حدّ فايل لانزياح القيم الذاتية وقارن بهوفمان–فيلانت إذا كان $\|E\|_F = 0.22$ و $n = 4$.

تمرين 15. استخدم كوران–فيشر لبيان أن $\lambda_2(A) \leq \lambda_2(B)$ إذا كان $B - A \succeq 0$.

تمرين 16. مصفوفة A بطيف $(7,\ 5,\ 1)$. احسب الفجوة الطيفية وحدّ ديفيس–كاهان على المتجه الذاتي الأول إذا $\|E\|_2 = 0.5$.

تمرين 17. تحقّق من التداخل (29.4) لحذف الصف/العمود الثالث من $A = \begin{bmatrix} 3 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 3 \end{bmatrix}$.

تمرين 18. بيّن أن $\lambda_{\max}(A+B) \leq \lambda_{\max}(A) + \lambda_{\max}(B)$ للمصفوفات المتماثلة.

إجابات مختصرة (ج): (13) $R = \frac{4\cdot1+2\cdot1\cdot2+2\cdot4}{5} = \frac{16}{5} = 3.2$؛ القيم الذاتية $\approx 4.414,\ 1.586$ $\Longrightarrow 1.586 \leq 3.2 \leq 4.414$ ✓. (14) فايل: 0.1 لكل قيمة؛ هوفمان: $\|\Delta\lambda\|_2 \leq 0.22$. (15) من (26.4): $R_A(x) \leq R_B(x)$ لكل x $\Longrightarrow$ min-max يتحقق. (16) $\sin\theta \leq 0.25 \Longrightarrow \delta = 2$ $\Longrightarrow \theta \leq 14.5°$. (17) $\lambda(A) \approx (4.414,\ 3,\ 1.586)$؛ $\lambda(B) = (4,\ 2)$ $\Longrightarrow 4.414 \geq 4 \geq 3 \geq 2 \geq 1.586$ ✓. (18) من (25.4): $R_{A+B}(x) = R_A(x) + R_B(x) \leq \lambda_{\max}(A) + \lambda_{\max}(B)$.

المجموعة د — طيف الرسم (19–24)

تمرين 19. احسب L وطيفه لرسم «مربع» C_4 وتحقّق أن $\lambda_{\max}(L_{\text{sym}}) = 2$.

تمرين 20. احسب متجه فيدلر لرسم المسار P_5 وحدّد التقسيم الناتج.

تمرين 21. بيّن أن $\lambda_2 = 0$ إذا وفقط إذا كان الرسم غير متصل.

تمرين 22. احسب ثابت شيغير لرسم الدورة C_6 وتحقّق من (36.4).

تمرين 23. احسب طيف الرسم الكامل K_4 غير المطبَّع والمطبَّع.

تمرين 24. صف مرشّحاً طيفياً يُبقي الترددات المتوسطة ويُزيل المنخفضة والعالية (band-pass) بصيغة كثيرات حدود في L.

إجابات مختصرة (د): (19) $\lambda(L) = (0, 2, 2, 4)$؛ $\lambda(L_{\text{sym}}) = (0, 1, 2, 1)$. ✓ (20) $v_1(i) = \cos\frac{\pi(i-0.5)}{5}$ $\Longrightarrow$ $f \approx (0.601,\ 0.372,\ 0,\ -0.372,\ -0.601)$ $\Longrightarrow$ التقسيم $\{1,2\} \mid \{4,5\}$ والعقدة 3 عند الصفر تُضاف للأقرب. (21) من (33.4): $\text{mult}(0) \geq 2$ $\Longleftrightarrow$ غير متصل. (22) لأي S متصل من k عُقد: $|\partial S| = 2$، $\text{vol}\, S = 2k$ $\Longrightarrow$ النسبة $\frac{2}{\min(2k,\ 12-2k)}$ $\Longrightarrow$ الأدنى عند $k = 3$: $\frac{2}{6} = \frac{1}{3}$ $\Longrightarrow$ $h = \frac{1}{3}$، و $1 - \cos\frac{\pi}{3} = 0.5 \leq \frac{2}{3}$ $\Longrightarrow$ $\frac{1/9}{2} = 0.056 \leq 0.5 \leq \frac{2}{3}$. ✓ (23) $\lambda(L) = (0, 4, 4, 4)$؛ $\lambda(L_{\text{sym}}) = (0,\ \frac{4}{3},\ \frac{4}{3},\ \frac{4}{3})$. (24) $g(\lambda) = \lambda(\lambda_{\max} - \lambda)$ مضروباً بثابت، أي $g(L) = L(\lambda_{\max} I - L)$.

المجموعة هـ — بيرون–فروبينيوس و PageRank (25–30)

تمرين 25. احسب $\rho(A)$ ومتجه بيرون لـ $A = \begin{bmatrix} 1 & 2 \\ 3 & 1 \end{bmatrix}$.

تمرين 26. استخدم كولاتس–فيلانت بـ $x = (1,\ 1)^{\top}$ ثم $x = (1,\ 1.5)^{\top}$ لتضييق الحدود على $\rho(A)$ في التمرين السابق.

تمرين 27. ابنِ مصفوفة جوجل لرسم من 3 صفحات: $1 \to 2$، $1 \to 3$، $2 \to 1$، $3 \to 1$ بـ $\alpha = 0.15$ واحسب تكرارين.

تمرين 28. كم تكراراً يلزم لتقارب PageRank بدقة 10^{-4} إذا كان $\alpha = 0.2$؟

تمرين 29. بيّن أن $|\lambda_2(G)| \leq 1 - \alpha$ باستخدام حقيقة أن كل صفوف G موجبة بالقدر α/n.

تمرين 30. احسب درجات HITS (hubs و authorities) للرسم الموجّه $A = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$.

إجابات مختصرة (هـ): (25) $\lambda^2 - 2\lambda - 5 = 0$ $\Longrightarrow$ $\rho = 1 + \sqrt{6} = 3.449$؛ $v \propto (\sqrt{2},\ \sqrt{3})^{\top}$ $\Longrightarrow$ $v = (0.449,\ 0.551)^{\top}$ بـ $\|\cdot\|_1$. (26) $x = (1,1)$: $Ax = (3,4)$؛ $\rho \in [3,\ 4]$ $\Longrightarrow$ نسب $4,\ 3$ $\Longrightarrow$ $x = (1, 1.5)$: $Ax = (4,\ 4.5)$؛ $\rho \in [3, 4]$ $\Longrightarrow$ (لا تحسّن $\Longrightarrow$ اختر x أقرب لبيرون). بـ $x = (0.45,\ 0.55)$: $Ax = (1.55,\ 1.90)$، نسب 3.444 و 3.455 $\Longrightarrow$ $\rho \in [3.444,\ 3.455]$ ✓ (الحقيقي 3.449). (27) $G = 0.05J + 0.85P$؛ $(\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ بالتناظر. (28) $k \geq \frac{\ln(5\times10^{-5})}{\ln 0.8} = \frac{-9.903}{-0.2231} = 44.4$ $\Longrightarrow$ 45 تكراراً. (29) كما في برهان (42.4): لأي $x \perp \mathbf{1}$ فإن $Gx = (1-\alpha)Px$. (30) $AA^{\top} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}$، $h = (0,\ 0.526,\ 0.851)^{\top}$ $\Longrightarrow$ $A^{\top}A = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix}$؛ و $\lambda_1 \approx 2.857$ $\Longrightarrow$ $a \approx (0.404,\ 0.660,\ 0.635)^{\top}$ تقريباً.

جدول النظريات الخمس

#	النظرية / القانون	الصيغة الجوهرية	التطبيق الرئيسي في الذكاء الاصطناعي
1	**التحليل الطيفي**	$A = Q\Lambda Q^\top = \sum_i \lambda_i q_i q_i^\top$، وكايلي–هاملتون، ودوال المصفوفات	PCA، التبييض، Neural ODE، استقرار التدريب
2	**SVD** + إيكارت–يونغ	$A = U\Sigma V^\top$؛ أفضل تقريب رتبة k بخطأ σ_{k+1} (طيفي) و $\sqrt{\sum_{i>k}\sigma_i^2}$ (فروبينيوس)	الضغط، LoRA، LSA، إكمال المصفوفات، التطبيع الطيفي
3	رايلي–ريتز وفايل	$\lambda_k = \min\max R_A(x)$؛ $\lvert\lambda_i(A+E)-\lambda_i(A)\rvert \le \lVert E\rVert_2$؛ $\sin\theta \le \lVert E\rVert_2/\delta$	ضبط معدّل التعلّم، تحليل التكميم، استقرار PCA
4	طيف اللابلاس وفيدلر	$L = D - W$؛ $x^\top Lx = \sum w_{ij}(x_i - x_j)^2$؛ λ_2 يحكم القطع وشيغير	التجميع الطيفي، GNN، تقسيم الصور، كشف المجتمعات
5	بيرون–فروبينيوس	$\rho(A)$ بسيطة بمتجه موجب؛ $\pi = \pi G$؛ $\lVert\lambda_2\rVert \le 1-\alpha$	PageRank، مركزية العُقد، أنظمة التوصية، كشف الاحتيال

المبادئ الخمسة الحاكمة

١. **الاتجاهات التي لا تُدار:** القيم الذاتية تخبرنا أين «يتمدّد» التحويل وأين «ينضغط»؛ هذه هي محاور البيانات.

٢. **الرتبة الفعّالة $\ll$ البعد الظاهري:** منحنى القيم المفردة هو أهم أداة تشخيص في تعلم الآلة؛ «الكوع» يحدّد البعد الحقيقي.

٣. **الفجوة الطيفية هي عملة الاستقرار:** فجوة كبيرة $\Longrightarrow$ متجهات مستقرّة وتقارب سريع؛ فجوة صغيرة $\Longrightarrow$ انهيار.

٤. **الاضطرابات محدودة بمتراجحات:** فايل للقيم، هوفمان–فيلانت للمجموع، ديفيس–كاهان للمتجهات، كوشي للتداخل.

٥. **الإيجابية تمنح الوحودية:** المصفوفات غير السالبة تعطي متجهاً ذاتياً موجباً وحيداً $\Longrightarrow$ ترتيبٌ «عادل» وحيد.

مسار القراءة للأجزاء القادمة

طيف المصفوفات هو الأداة التي سنحتاجها في:

- **الجزء الثاني (التفاضل والتكامل):** الهسيان (مصفوفة متماثلة) $\Longrightarrow$ القيم الذاتية تحدّد نوع النقطة الحرجة وسرعة التقارب.
- **الجزء الثالث (الاحتمالات):** مصفوفات التغاير $\Longrightarrow$ PCA الاحتمالي والعوامل الكامنة.
- **الجزء الرابع (التحسين):** رقم الحالة $\kappa = \sigma_1/\sigma_n$ $\Longrightarrow$ سرعة التدرّج وطرق نيوتن.
- **الجزء السابع (رياضيات التعلم العميق):** Kernel Tangent Neural $\Longrightarrow$ طيف NTK يحكم التعميم؛ ومصفوفات الانتباه $\Longrightarrow$ طيفها يحكم الاستقرار.
- **الجزء الثامن (البنى المتقدمة):** الهندسة المعلوماتية $\Longrightarrow$ مترية فيشر، والنقل الأمثل $\Longrightarrow$ طيف نواة النقل.

القيم الذاتية والتحليل الطيفي

الرمز	المعنى
λ	القيمة الذاتية (eigenvalue)
λ_i	القيمة الذاتية رقم i (تنازلياً في §٤.٤–٢.٤، تصاعدياً في §٥.٤)
$v,\ q,\ u_i$	المتجه الذاتي (eigenvector)
Λ	مصفوفة قطرية للقيم الذاتية

مصفوفة متعامدة للمتجهات الذاتية	Q
كثيرة الحدود المميِّزة	$p_A(\lambda)$
طيف A (مجموعة قيمها الذاتية)	$\mathrm{spec}(A)$
التكرار الجبري	$\mathrm{alg}(\lambda)$
التكرار الهندسي	$\mathrm{geo}(\lambda)$
الأثر (trace)	$\mathrm{tr}(A)$
المحدِّد	$\det(A)$
موجب التحديد / نصف موجب التحديد	$\succ,\ \succeq$
نصف القطر الطيفي	$\rho(A)$
الأُسّ الماتريسي	e^{At}
دالة المصفوفة	$f(A)$
خارج قسمة رايلي	$R_A(x)$
الفجوة الطيفية	δ
رقم الحالة	$\kappa(A)$

القيم المفردة والرتبة

المعنى	الرمز
القيمة المفردة رقم i	σ_i
مصفوفة القيم المفردة	Σ
المتجهات المفردة اليسرى واليمنى	$U,\ V$
المتجه المفرد الأيسر/الأيمن	$u_i,\ v_i$
رتبة المصفوفة	r
الرتبة المستهدفة في التقريب	k
النورم الطيفي	$\|\cdot\|_2$
نورم فروبينيوس	$\|\cdot\|_F$
النورم النووي	$\|\cdot\|_*$
المعكوس الشمولي	$A^\dagger$
الأشكال المقتطعة (thin)	$U_k,\ \Sigma_k,\ V_k$

الرسوم والاضطراب

المعنى	الرمز
الرسم البياني	$G = (V, E)$
مصفوفة المجاورة	W
مصفوفة الدرجات	D
لابلاس الرسم	L
اللابلاس المطبَّع تماثلياً	L_{sym}
لابلاس السير العشوائي	L_{rw}
متجه فيدلر	f
ثابت شيغير	$h(G)$
حجم مجموعة العُقَد	$\mathrm{vol}(S)$
حدود المجموعة (الروابط المقطوعة)	∂S
مصفوفة الاضطراب	E
المصفوفة المضطربة	$\hat{A}$
مصفوفة الزوايا الرئيسية	$\Theta(U, \hat{U})$
مرشِّح طيفي على الرسم	$g(L)$

بيرون–فروبينيوس و PageRank

الرمز	المعنى
$A \geq 0$	مصفوفة غير سالبة
α	معامل التخفيف (teleport)
P	مصفوفة الانتقال
G	مصفوفة جوجل
π	توزيع PageRank
c	مركزية المتجه الذاتي
$h,\ a$	درجات المراكز والسلطات (HITS)
$\mathbf{1}$	متجه الواحدات
$J = \mathbf{1}\mathbf{1}^\top$	مصفوفة الواحدات

١. **G. Strang,** (2016). *Introduction to Linear Algebra*, 5th ed. Wellesley-Cambridge Press. — الفصول 6 و 7: القيم الذاتية و SVD.

٢. **D. Bau, & N., L. Trefethen,** (1997). *Numerical Linear Algebra*. SIAM. — المحاضرات 4–5 و 24–31: SVD والخوارزميات الطيفية.

٣. **F. C. Loan, Van & H., G. Golub,** (2013). *Matrix Computations*, 4th ed. Johns Hopkins. — المرجع الحسابي الشامل.

٤. **R. C. Johnson, & A., R. Horn,** (2012). *Matrix Analysis*, 2nd ed. Cambridge University Press. — متراجحات فايل وهوفمان–فيلانت وكوران–فيشر.

٥. **R. C. Johnson, & A., R. Horn,** (1991). *Topics in Matrix Analysis*. Cambridge. — بيرون–فروبينيوس بتفصيل وافٍ.

٦. **D. C. Meyer,** (2000). *Matrix Analysis and Applied Linear Algebra*. SIAM. — الفصل 7: القيم الذاتية، والفصل 8: بيرون–فروبينيوس و PageRank.

٧. **G. Young, & C., Eckart,** (1936). «The approximation of one matrix by another of lower rank». *Psychometrika* 1 (3), 211–218. — الأصل التاريخي لنظرية التقريب الأمثل.

٨. **L. Mirsky,** (1960). «Symmetric gauge functions and unitarily invariant norms». *Q. J. Math.* 11, 50–59. — التعميم لأي نورم ثابت وحدوياً.

٩. **M. W. Kahan, & C., Davis,** (1970). «The rotation of eigenvectors by a perturbation. III». *SIAM J. Numer. Anal.* 7 (1), 1–46. — متراجحة ديفيس–كاهان.

١٠. **J. Sun, & W., G. Stewart,** (1990). *Matrix Perturbation Theory*. Academic Press. — المرجع الكامل لنظرية الاضطراب.

١١. **K. R. F. Chung,** (1997). *Spectral Graph Theory*. AMS/CBMS. — المرجع الكلاسيكي لطيف الرسوم ومتراجحة شيغير.

١٢. **U. Luxburg, Von** (2007). «A tutorial on spectral clustering». *Statistics and Computing*, 17 (4), 395–416. — العرض المرجعي للتجميع الطيفي والفجوة الطيفية.

١٣. **M. Fiedler,** (1973). «Algebraic connectivity of graphs». *Czechoslovak J. Math.* 23, 298–305. — الأصل التاريخي لمتجه فيدلر.

١٤. **V. Milman, & N., Alon,** (1985). «λ_1, isoperimetric and graphs, for inequalities superconcentrators». *J. Combin. Theory B*, 38, 73–88. — العلاقة بين λ_2 وثابت شيغير.

١٥. **M. Welling, & N., T. Kipf,** (2017). «Semi-supervised classfiication with graph convolutional networks». *ICLR*. — صيغة GCN الطيفية.

١٦. **P. Vandergheynst, & X., Bresson, M., Defferrard,** (2016). «Convolutional neural networks on graphs with fast localized spectral filtering». *NeurIPS*. — مرشّح تشيبيشيف (ChebNet).

١٧. **T. Winograd, & R., Motwani, S., Brin, L., Page,** (1999). «The citation PageRank ranking». *Report Tech Stanford*. — الأصل التاريخي.

١٨. **D. C. Meyer, & N., A. Langville,** (2006). *Google's PageRank and Beyond*. Princeton University Press. — التحليل الشامل لـ PageRank و HITS.

١٩. **M. J. Kleinberg,** (1999). «Authoritative sources in a hyperlinked environment». *J. ACM*, 46(5), 604–632. — خوارزمية HITS.

٢٠. **T., Miyato, et al.** (2018). «Spectral normalization for generative adversarial networks». *ICLR*. — التطبيع الطيفي في GAN.

٢١. **E. Hu, J., et al.** (2022). «LoRA: Low-rank adaptation of large language models». *ICLR*. — التقريب من رتبة منخفضة في الضبط الدقيق.

٢٢. **S., Kornblith, et al.** (2019). «Similarity of neural network representations revisited». *ICML*. — CKA والزوايا الرئيسية لمقارنة التمثيلات.

٢٣. **M. Wofl, & O., Ledoit,** (2004). «A well-conditioned estimator for large-dimensional covariance matrices». *J. Multivariate Anal.*, 88, 365–411. — تقدير التغاير بالانكماش (shrinkage).

الفصل القادم: النواظم (Norms)، المسافات، ومتراجحات المصفوفات — حيث نعمّم مفهوم «الطول» و«المسافة» على فضاءات المصفوفات والدوال، ونبني المتراجحات التي يقوم عليها الاستقرار العددي والتعميم في تعلم الآلة.

الفصل ٥

النواظم، (Norms) المسافات، ومتراجحات المصفوفات

الهدف من الفصل

أن تعطي معنى دقيقاً لكلمة «طول» و«مسافة» و«قرب» في فضاءات المتجهات والمصفوفات والدوال، ثم أن تمتلك **المتراجحات** — وهي الأداة التي تحوّل «الطول» إلى **ضمان**: ضمان تقارب، ضمان استقرار، ضمان تعميم، ضمان متانة أمام الاضطراب. كل حدّ تعميم (generalization bound) وكل تحليل استقرار وكل إثبات تقارب في تعلم الآلة هو في جوهره متراجحة على ناظم.

لماذا هذا الفصل هو «لُغة الحدود» في الكتاب؟

في الفصول السابقة تعلّمنا **بنية** الفضاء (المجموعات، الفضاءات المتجهة، المصفوفات، القيم الذاتية). في هذا الفصل نتعلّم **القياس**: كم يبعد شيء عن شيء؟ وكم يمكن أن يكبر خطأ؟ وكم يلزم من البيانات؟

السؤال في الذكاء الاصطناعي	الناظم/المتراجحة التي تجيب عنه
هل سيتقارب التدرّج العشوائي (SGD)؟	الناظم الإقليدي + متراجحة المثلث + التضاعف التحتي
هل النموذج متين أمام اضطراب في المدخلات (adversarial)؟	ℓ_2 و ℓ_∞ وناظم المشغّل $\|W\|_2$ (ثابت ليبشيتز)
كيف نحصل على نموذج متناثر (sparse)؟	كرة ℓ_1 لها زوايا $\Rightarrow$ تدفع الحل إلى الصفر (Lasso)
كيف نكمل مصفوفة ناقصة (توصية)؟	الناظم النووي $\|A\|_*$ بديل مقعّب للرتبة
كيف نضغط الأوزان أو نقيس «حجم» التحديث؟	نواظم شاتن: $\|A\|_2$، $\|A\|_F$، $\|A\|_*$
هل توزيعان قريبان؟	مسافات على التوزيعات: KL، TV، Wasserstein
كم بُعداً نحتاج لنحفظ المسافات؟	لمّا جونسون–ليندنشتراوس (JL)
هل سينفجر التدرّج أم يتلاشى؟	حاصل ناظم المشغّل: $\prod_k \|W_k\|_2$ وتركيز ناظم المصفوفة العشوائية
هل التضمينات (embeddings) تحفظ المعنى؟	تركيز النواظم + متراجحة المثلث على المسافات

خريطة الفصل

القسم	الموضوع	القوانين/النظريات	عدد الأمثلة المحلولة
1.5	المفردات: مسلّمات الناظم، المترية، نواظم ℓ_p	(1.5)–(7.5)	—
2.5	متراجحات كوشي–شفارتس وهولدر ومينكوفسكي + الناظم الثنوي	(8.5)–(12.5)	15
3.5	تكافؤ النواظم في الأبعاد المنتهية وحدود التحويل	(13.5)–(18.5)	15
4.5	النواظم المصفوفية المستحثة والتضاعف التحتي ونصف القطر الطيفي	(19.5)–(25.5)	15
5.5	نواظم شاتن ومتراجحة فون نيومان للأثر وازدواج النواظم المصفوفية	(26.5)–(32.5)	15
6.5	تركّز النواظم ولمّا جونسون–ليندنشتراوس وناظم المصفوفة العشوائية	(33.5)–(39.5)	15
7.5	تمارين محلولة ومفتوحة (30 تمريناً)	—	—
8.5	خلاصة الفصل	—	—
9.5	فهرس الرموز	—	—
10.5	المراجع	—	—

كيف تقرأ هذا الفصل

كل نظرية تأتي في **أربع طبقات** إلزامية:

١. **صياغة رسمية** في كتلة معادلة مستقلة مرقّمة بـ \tag{}.

٢. **جدول رموز** يشرح كل رمز ومعامل في المعادلة.

٣. **رسم هندسي** (SVG) يترجم المعادلة إلى صورة.

٤. **برهان** كامل أو مرجعي.

ثم خمس طبقات تطبيقية: 15 مثالاً واقعياً محلولاً بخطوات مرقّمة ⟵ جدول أخطاء شائعة ⟵ تمارين ⟵ فهرس رموز ⟵ مراجع.

> **قاعدة ذهبية تسبق كل شيء:** في تعلم الآلة لا تختار الناظم لأنه «أدقّ»، بل لأن **كرة الوحدة** الخاصة به لها الشكل الذي يخدم هدفك: كرة ℓ_1 مُعيَّنة الزوايا ⟹ تناثر؛ كرة ℓ_2 ملساء ⟹ استقرار عددي وتماسك؛ كرة ℓ_∞ مُربَّعة ⟹ أسوأ حالة على بُعد واحد؛ كرة الناظم النووي ⟹ رتبة منخفضة.

1.1.5 تعريف الناظم (Norm)

ليكن V فضاءً متجهاً على $\mathbb{R}$ (أو $\mathbb{C}$). **الناظم** (norm) على V هو دالة $\|\cdot\| : V \to \mathbb{R}$ تحقّق المسلّمات الأربع التالية لكل $x, y \in V$ وكل ثابت قياسي α:

(1.5)

$$x = 0 \iff \|x\| = 0, \quad \|x\| \geq 0$$ (N1) غير سالب ومحدِّد:

$$\|\alpha x\| = |\alpha|\,\|x\|$$ (N2) متجانس إطلاقاً:

$$\|x + y\| \leq \|x\| + \|y\|$$ (N3) متراجحة المثلث:

$$\|x\| = \sqrt{\langle x,\, x\rangle}$$ (N4) (لازم للدوال على الفضاءات الداخلية) الارتباط بالضرب الداخلي:

جدول رموز (1.5):

الرمز	المعنى	ملاحظات
V	فضاء متجهي (vector space) على $\mathbb{R}$ أو $\mathbb{C}$	قد يكون $\mathbb{R}^n$، أو فضاء مصفوفات، أو فضاء دوال
$\|\cdot\|$	الناظم: دالة من V إلى $\mathbb{R}_{\geq 0}$	تُقرأ «ناظم x» = «norm of x»
x, y	متجهات (أو مصفوفات، أو دوال) عناصرُ الفضاء V	—
α	ثابت قياسي (scalar) من حقل الفضاء $\mathbb{R}$ أو $\mathbb{C}$	—
$\|\alpha\|$ في (N2)	القيمة المطلقة لـ α (أو معيارها المركّب)	تكتب $\|\alpha\|$ — بخطّين عموديين صغيرين
0	متجه الصفر في V	(N1) تقول: الصفر وحده ناظمه صفر
$\langle x, y\rangle$	الضرب الداخلي (inner product)	يُولّد ناظماً عبر $\|x\| = \sqrt{\langle x, x\rangle}$
(N1)	«positive definiteness» — اللاسلبية والتحديد	بدونه نحصل على «شبه ناظم» (seminorm)
(N2)	«absolute homogeneity» — التجانس المطلق	يمنع تضخم الناظم بالسالب
(N3)	«triangle inequality» — متراجحة المثلث	هي التي تجعل الناظم «مسافة»
(N4)	الشرط الإقليدي: الناظم آتٍ من ضرب داخلي	ليس كل ناظم يحقّقه: ℓ_1 وℓ_∞ لا يحقّقانه
$\iff$	«إذا وفقط إذا»	في (N1) تقرأ: «ناظم x يساوي صفراً **إذا وفقط إذا** كان x نفسه صفراً»

ملاحظة: إذا سقط شرط $\|x\| = 0 \Rightarrow x = 0$ فقط، صارت الدالة **شبه ناظم** (seminorm). مثال مهم في تعلم الآلة: $\|f\| = \|Wf\|_2$ حيث W غير قابلة للعكس — فهي تلغي اتجاهات كاملة.

2.1.5 الناظم يُولّد مترية (مسافة)

كل ناظم يُولّد **مسافة** (metric) / (distance بالعلاقة:

$$d(x,\,y) \;=\; \|\,x - y\,\| \tag{2.5}$$

وهذه المسافة تحقّق مسلّمات المترية الأربع:

$$\begin{aligned}
&\text{(M1)} \quad d(x,y) \geq 0, \quad d(x,y) = 0 \iff x = y \\
&\text{(M2)} \quad d(x,y) = d(y,x) \quad \text{(تناظر)} \\
&\text{(M3)} \quad d(x,z) \leq d(x,y) + d(y,z) \quad \text{(متراجحة المثلث)} \\
&\text{(M4)} \quad d(x+a,\;y+a) = d(x,y) \quad \text{(ثبات بالانتقال — يتبع من التجانس المطلق)}
\end{aligned} \tag{3.5}$$

جدول رموز (2.5)–(3.5):

الرمز	المعنى	ملاحظات
$d(x,y)$	المسافة بين x و y	القيمةُ عددٌ حقيقي غير سالب
$x-y$	فرق المتجهين	في فضاء المتجهات يُعرَّف بالطرح المعتاد
(M1)	المسافة لاسالبة وتصفّر **فقط** عند التطابق	يتبع من (N1)
(M2)	التناظر	يتبع من (N2) مع $\alpha=-1$: $\|x-y\| = \|-(y-x)\| = \|y-x\|$
(M3)	متراجحة المثلث للمسافة	يتبع من (N3): $x-z = (x-y)+(y-z)$
(M4)	الثبات بالانتقال (translation invariance)	خاصية تميّز المسافات الآتية من ناظم
a	متجه انتقال (offset) اختياري	—

تنبيه: ليست كل مسافة آتية من ناظم. أمثلة مهمة في تعلم الآلة: مسافة كولباك–ليبلر (ليست مترية: غير متناظرة، ولا تحقّق المثلث)، ومسافة جنسن–شانون (مترية بعد أخذ الجذر)، ومسافة واسرشتاين (مترية حقيقية وآتية من ناظم على فضاء دوال مزدوج). سنفصّلها في الجزء الخامس (نظرية المعلومات) والجزء الثامن.

3.1.5 عائلة نواظم ℓ_p

أهم عائلة نواظم على $\mathbb{R}^n$ هي عائلة ℓ_p المعرّفة لكل $p \in [1,\infty]$ بـ:

$$\|x\|_p \;=\; \begin{cases} \Big(\displaystyle\sum_{i=1}^{n} |x_i|^p\Big)^{1/p}, & 1 \leq p < \infty \\[2mm] \displaystyle\max_{1\leq i\leq n} |x_i|, & p = \infty \end{cases} \tag{4.5}$$

الحالات الثلاث الأكثر استخداماً:

$$\|x\|_1 = \sum_{i=1}^{n} |x_i|, \qquad \|x\|_2 = \sqrt{\sum_{i=1}^{n} x_i^2}, \qquad \|x\|_\infty = \max_i |x_i| \tag{5.5}$$

جدول رموز (4.5)–(5.5):

الرمز	المعنى	ملاحظات
p	أُسّ الناظم، (order) عدد حقيقي في $[1, \infty]$	ليس عدداً طبيعياً بالضرورة
x_i	الإحداثي (المكوّن) رقم i للمتجه x	$x = (x_1, \dots, x_n)^\top$
$\|x_i\|$ في الصيغة	القيمة المطلقة للإحداثي	مكتوبة $\|x_i\|$
$\sum_{i=1}^{n}$	مجموع على كل الإحداثيات من 1 إلى n	—
$(\cdot)^{1/p}$	الجذر الـ p	يضمن التجانس (N2)
n	بُعد الفضاء	يظهر صراحةً في حدود التحويل بين النواظم
$\max_i$	أكبر إحداثي بالمقياس المطلق	حالة $p = \infty$
$\|x\|_1$	«ناظم مانhattan» أو ناظم مجموع القيم المطلقة	يولّد التناثر
$\|x\|_2$	الناظم الإقليدي	الناظم الوحيد الآتي من الضرب الداخلي القياسي
$\|x\|_\infty$	ناظم «أقصى قيمة مطلقة» = ناظم تشيبيشيف	يضبط أسوأ حالة
$0 < p < 1$	**ليس** ناظماً: ينكسر (N3)	يولّد «شبه ناظم» مقعّب محلياً فقط

تحذير شائع: الصيغة $\|x\|_p = (\sum |x_i|^p)^{1/p}$ عند $0 < p < 1$ **لا تُعطي ناظماً** لأن متراجحة المثلث **تفشل. مثال:** $x = (1,0),\ y = (0,1)$ على $\mathbb{R}^2$ مع $p = \frac{1}{2}$: $\|x + y\|_{1/2} = 4 > 2 = \|x\|_{1/2} + \|y\|_{1/2}$. لهذا تُستخدم ℓ_p بـ $p < 1$ فقط كـ «بديل مقعّب للتناثر» مع خوارزميات خاصّة.

4.1.5 الناظم الآتي من ضرب داخلي عام (ومصفوفة القياس)

كل مصفوفة G متماثلة موجبة التحديد (SPD) تُعرّف ناظماً عبر:

$$\|x\|_G = \sqrt{x^\top G\, x}, \qquad G = G^\top \succ 0 \tag{6.5}$$

وهذا يعمّم الناظم الإقليدي (الذي يقابل $G = I$). في تعلم الآلة يظهر هذا بصيغتين:

$$d_M(x,y) = \sqrt{(x-y)^\top M (x-y)} \quad ; \quad \text{(Metric learning)} \qquad d_G(x,y) = \sqrt{(x-y)^\top \Sigma^{-1} (x-y)} \quad \text{(Mahalanobis)} \tag{7.5}$$

جدول رموز (6.5)–(7.5):

الرمز	المعنى	ملاحظات
G	مصفوفة القياس (metric matrix)	$n \times n$
$G = G^\top$	G متماثلة	شرط لازم ليكون الضرب الداخلي متناظراً
$G \succ 0$	G موجبة التحديد: $x^\top G x > 0$ لكل $x \neq 0$	شرط لازم لـ (N1)
$x^\top G x$	الشكل التربيعي (quadratic form)	عدد حقيقي ≥ 0
$\sqrt{\cdot}$	الجذر التربيعي	يحقّق التجانس (N2)
Σ	مصفوفة التغاير (covariance) للبيانات	
Σ^{-1}	معكوس التغاير = مصفوفة الدقّة (precision matrix)	«يُبيّض» البيانات
d_G, d_M	مسافة مالانوبيس ومسافة متعلَّمة	يعاقب الاتجاهات عالية التباين
M	مصفوفة متعلَّمة (مثلاً $M = L^\top L$)	أساس تعلّم المسافة (metric learning) و kNN الموزون
I	مصفوفة الوحدة	غالباً تُقنَّن بـ $M \succeq 0$ وبأثر ثابت
		$G = I \Rightarrow \|x\|_G = \|x\|_2$

ملاحظة هندسية: كرة الوحدة $\{x : \|x\|_G \leq 1\}$ هي **قطع ناقص** محاورُه متجهاتُ G الذاتية، وأطوالُ أنصاف محاوره $1/\sqrt{\lambda_i(G)}$. هذا هو «الشكل» الذي تتخذه البيانات بعد التبييض (whitening): $x \mapsto \Sigma^{-1/2} x$.

الفكرة في سطر: الضرب الداخلي لمدخلين لا يمكن أن يتجاوز **حاصل ضرب طوليهما**، والفرق بينهما هو بالضبط جيبُ تمامِ الزاوية بينهما. هذه الحقيقة الواحدة — بعد تعميمها من ℓ_2 إلى أي زوج (p, q) مترافق — تُنتج كلَّ متراجحة أخرى في هذا الفصل.

1.2.5 الصياغة الرسمية

نظرية (كوشي–شفارتس — Cauchy–Schwarz).

ليكن V فضاءً بضرب داخلي، وليكن $x, y \in V$. عندئذٍ:

$$\begin{aligned} \big|\langle x,\, y\rangle\big| \;&\le\; \|x\|_2\,\|y\|_2 \\ \big|\langle x,\, y\rangle\big| = \|x\|_2\|y\|_2 \;&\iff\; \exists\,\alpha\in\mathbb{R}:\; y=\alpha x \;\text{ أو }\; x=\alpha y \end{aligned} \tag{8.5}$$

وإذا كان $x \neq 0$ و $y \neq 0$ فإن الزاوية θ بينهما تُعرَّف بالصيغة المكافئة:

$$\cos\theta \;=\; \frac{\langle x,\, y\rangle}{\|x\|_2\,\|y\|_2} \;\in\; [-1,\,1], \qquad \theta = \arccos\!\left(\frac{\langle x,\, y\rangle}{\|x\|_2\|y\|_2}\right)$$

جدول رموز (8.5):

الرمز	المعنى	ملاحظات
$\langle x, y\rangle$	الضرب الداخلي (inner product) بين x و y	على $\mathbb{R}^n$: $\langle x,y\rangle = \sum_i x_i y_i = x^\top y$
$\|\langle x, y\rangle\|$	القيمة المطلقة للضرب الداخلي	بدونها تفشل المتراجحة عند $\langle x,y\rangle$ سالب كبير
$\|x\|_2,\ \|y\|_2$	الناظمان الإقليديان: $\|x\|_2 = \sqrt{\langle x,x\rangle}$	حاصل ضربهما هو «السقف»
$\le$	المتراجحة: الطرف الأيسر $\le$ الطرف الأيمن دائماً	تساوي فقط عند التوازي
$\iff$	«إذا وفقط إذا» — شرط التساوي	يفيد في كشف التبعية الخطية
α	ثابت التناسب (أي عدد حقيقي)	قد يكون صفراً أو سالباً
$\cos\theta$	جيب تمام الزاوية بين المتجهين	قيمته في $[-1,1]$ بفضل كوشي–شفارتس
θ	الزاوية بالراديان (أو بالدرجات)	$\theta=0$: نفس الاتجاه؛ $\theta=\pi$: اتجاهان متعاكسان؛ $\theta=\pi/2$: تعامد
arccos	الدالة العكسية لجيب التمام	مداها $[0,\pi]$ راديان
$x \neq 0$	شرط لتجنّب القسمة على صفر	إذا كان أحدهما صفراً فالزاوية غير معرّفة

نظرية (هولدر — Hölder).

ليكن $p, q \in [1,\infty]$ **أُسّين مترافقين** (conjugate exponents)، أي $\frac{1}{p}+\frac{1}{q}=1$. عندئذٍ لكل $x, y \in \mathbb{R}^n$:

$$\sum_{i=1}^{n}\big|x_i\,y_i\big| \;=\; \big\|\,x\odot y\,\big\|_1 \;\le\; \|x\|_p\,\|y\|_q \tag{9.5}$$

بصيغة الضرب الداخلي: $|\langle x,y\rangle| \le \sum_i |x_i y_i| \le \|x\|_p\|y\|_q$. **والحالات الحدّية:** $(p,q) = (1,\infty)$ و $(p,q)=(2,2)$ — والأخيرة هي بالضبط كوشي–شفارتس.

جدول رموز (9.5):

الرمز	المعنى	ملاحظات
p	أُسّ الناظم الأول	$1 \le p \le \infty$
q	أُسّ الناظم الثاني = الأُسّ المترافق	$1 < p < \infty$ عندما $q = \frac{p}{p-1}$
$\frac{1}{p} + \frac{1}{q} = 1$	**شرط الترافق** (conjugacy)	جوهري: بدونه تفشل المتراجحة
x_i, y_i	الإحداثيّان رقم i في المتجهين	—
$\lvert x_i y_i \rvert$	القيمة المطلقة لجداء الإحداثيين	—
$\sum_{i=1}^{n}$	المجموع على كل الإحداثيات	—
$x \odot y$	جداء هادامارد (إحداثياً بإحداثي)	$(x \odot y)_i = x_i y_i$
$\lVert x \odot y \rVert_1$	مجموع قيم جداء هادامارد المطلقة	مساوٍ للطرف الأيسر
$\lVert x \rVert_p$	ناظم ℓ_p للمتجه x	$(\sum \lvert x_i \rvert^p)^{1/p}$
$\lVert y \rVert_q$	ناظم ℓ_q للمتجه y	—
$p = 1, q = \infty$	الحالة الحدية الأولى: $\sum \lvert x_i y_i \rvert \le \lVert x \rVert_1 \lVert y \rVert_\infty$	أساس تحليل المتانة بـ ℓ_∞
$p = q = 2$	الحالة الحدية الثانية = كوشي–شفارتس	الحالة «الذاتية الترافق»
$q = p/(p-1)$	صيغة حساب الأُسّ المترافق	$p = 4 \Rightarrow q = 4/3$ ،$p = 1.5 \Rightarrow q = 3$

نظرية (مينكوفسكي — Minkowski = متراجحة المثلث لـ ℓ_p).

لكل $1 \le p \le \infty$ وكل $x, y \in \mathbb{R}^n$:

$$\lVert x + y \rVert_p \;\le\; \lVert x \rVert_p + \lVert y \rVert_p \tag{10.5}$$

وبالتعميم على أي عدد من الحدود وبالصيغة الفرقية:

$$\Big\lVert \sum_{k=1}^{K} x^{(k)} \Big\rVert_p \;\le\; \sum_{k=1}^{K} \lVert x^{(k)} \rVert_p, \qquad \big|\, \lVert x \rVert_p - \lVert y \rVert_p \,\big| \;\le\; \lVert x - y \rVert_p \tag{10b.5}$$

جدول رموز (10.5):

الرمز	المعنى	ملاحظات
$x + y$	مجموع المتجهين إحداثياً بإحداثي	$(x+y)_i = x_i + y_i$
$\lVert x + y \rVert_p$	ناظم ℓ_p للمجموع	الطرف الأيسر: «طول الضلع الثالث»
$\lVert x \rVert_p + \lVert y \rVert_p$	مجموع ناظمي الضلعين	الطرف الأيمن: «طول الطريق عبر y»
$1 \le p \le \infty$	مجال الأُسّ الذي تصحّ فيه المتراجحة	عند $p < 1$ **تفشل** المتراجحة
$x^{(k)}$	المتجه رقم k في مجموعة من K متجهات	العلوي بين قوسين: رقم المتجه لا أُسّ
K	عدد المتجهات المجموعة	مثلاً عدد خطوات التراكم في التدرّج
$\lVert x \rVert_p - \lVert y \rVert_p$	فرق الناظمين	القيمة المطلقة تمحي من الإشارة
يمين (10b.5)	**المتراجحة الفرقية** (reverse triangle)	تضبط «كم يمكن أن يختلف الناظمان»
$\le$	اتجاه المتراجحة: «المباشر أقصر من الملتوي»	—

تعريف (الناظم الثنوي — Dual norm).

لكل ناظم $\lVert \cdot \rVert$ على $\mathbb{R}^n$ نعرّف ناظمه الثنوي:

$$\lVert z \rVert_* \;=\; \sup\big\{\, \langle z,\, x \rangle \;:\; \lVert x \rVert \le 1 \,\big\} \;=\; \max_{\lVert x \rVert = 1} \langle z,\, x \rangle \tag{11.5}$$

ويتحقّق: **(أ)** المتراجحة المعمّمة $\lvert \langle z, x \rangle \rvert \le \lVert z \rVert_* \, \lVert x \rVert$؛ **(ب)** $(\ell_p)^* = \ell_q$ بالترافق $\frac{1}{p} + \frac{1}{q} = 1$؛ **(ج)** $(\lVert \cdot \rVert_*)^* = \lVert \cdot \rVert$ (ثنوية الثنوي يعيد الأصل)؛ **(د)** $\lVert z \rVert = \max_{\lVert w \rVert_* \le 1} \langle z, w \rangle$.

جدول رموز (11.5):

الرمز	المعنى	ملاحظات
z	المتجه المراد قياس ناظمه الثنوي	يلعب دور «الوحشة» أو «الشكل الخطي»
$\|\cdot\|_*$	الناظم الثنوي (dual norm)	النجمة علامة الاصطلاح
sup	الحدّ الأعلى (supremum) للمجموعة	هنا يتحقّق كـ max لأن كرة الوحدة متراصّة
$\{\,\|x\| \le 1\,\}$	كرة الوحدة المغلقة للناظم الأصلي	مجموعة الاختبار
$\langle z, x\rangle$	الشكل الخطي الذي نُعظّمه	إسقاط x على z
$\max_{\|x\|=1}$	التعظيم على سطح الكرة	يكافئ التعظيم على الكرة لأن الشكل خطي
$(\ell_p)^* = \ell_q$	ثنوي ℓ_p هو ℓ_q	$p=2 \Rightarrow q=2$، $p=1 \Rightarrow q=\infty$
$(\|\cdot\|_*)_* = \|\cdot\|$	الازدواج انعكاسي (reflexive)	صحيح في الأبعاد المنتهية دائماً
$\|z\| = \max_{\|w\|_*\le 1}\langle z, w\rangle$	إعادة بناء الناظم من ثنويه	كل ناظم = دالة دعم لكرته الثنوية
w	متجه الاختبار في صيغة إعادة البناء	يتراوح على الكرة الثنوية

لمّة (يونغ — Young) — أداة البرهان:

$$a\,b \;\le\; \frac{a^p}{p} + \frac{b^q}{q}, \qquad a,b \ge 0, \quad \tfrac{1}{p}+\tfrac{1}{q}=1 \tag{12.5}$$

الرمز	المعنى	ملاحظات
a, b	عددان حقيقيان غير سالبين	يمثّلان $\|x_i\|$ و $\|y_i\|$ بعد التطبيع
a^p/p	الجزء الأول من حدّ يونغ	الأُسّ p يقابل الناظم الأول
b^q/q	الجزء الثاني من حدّ يونغ	الأُسّ q المترافق
p, q	الأُسّان المترافقان	$1/p + 1/q = 1$
التساوي	يتحقّق عند $a^p = b^q$	وهو ما يعطي شرط التساوي في هولدر

الشكل الهندسي للمتراجحة (8.5): الإسقاطُ أقصرُ من المتجه، والمسافةُ بينهما هي «الجزء المتعامد» من y على x:

$$\big\| y - \operatorname{proj}_x y \big\|_2^2 \;=\; \|y\|_2^2 - \frac{\langle x,y\rangle^2}{\|x\|_2^2} \;=\; \|y\|_2^2\big(1-\cos^2\theta\big)$$

شكل الناظم الثنوي: المستوى الداعم للكرة في النقطة المُعظِّمة:

2.2.5 البرهان

برهان كوشي-شفارتس (8.5).

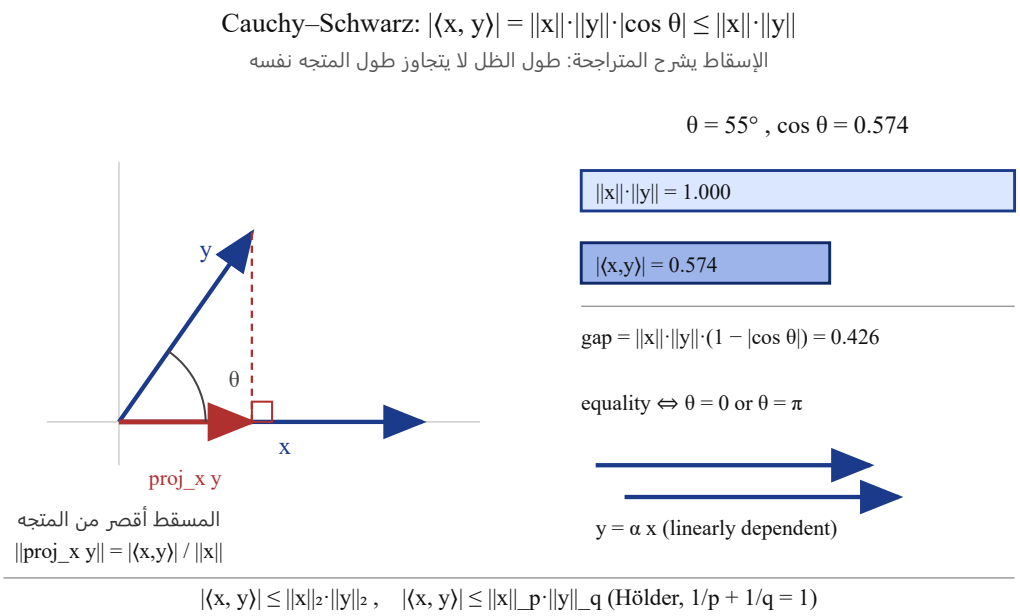
إذا كان $y = 0$ فالمتراجحة بديهية $(0 \le 0)$. وإلا، فليكن $\alpha \in \mathbb{R}$ حرّاً، ومن (N1) مع المتجه $x - \alpha y$:

$$0 \;\le\; \|x - \alpha y\|_2^2 \;=\; \|x\|_2^2 - 2\alpha\langle x,y\rangle + \alpha^2\|y\|_2^2$$

الطرف الأيمن كثيرُ حدودٍ تربيعي في α لا سالب أبداً، فمميّزه غير موجب:

$$\Delta \;=\; 4\langle x,y\rangle^2 - 4\|x\|_2^2\|y\|_2^2 \;\le\; 0 \quad\Longrightarrow\quad \langle x,y\rangle^2 \le \|x\|_2^2\|y\|_2^2$$

وبأخذ الجذر: $|\langle x,y\rangle| \le \|x\|_2\|y\|_2$. والتساوي يعني $\Delta = 0$، أي وجود جذر حقيقي مكرّر $\alpha^\star$ مع $\|x - \alpha^\star y\|_2 = 0$، أي $x = \alpha^\star y$. ■



شكل ١٠٥: *
متراجحة كوشي–شفارتس هندسياً: الإسقاط والزاوية

برهان هولدر (9.5).

بلا فقدان العمومية نفترض $\|x\|_p > 0$ و $\|y\|_q > 0$ (وإلا فأحدهما صفر والمتراجحة بديهية). نُطبّع:

$$\tilde{x}_i = \frac{|x_i|}{\|x\|_p}, \qquad \tilde{y}_i = \frac{|y_i|}{\|y\|_q} \quad \Longrightarrow \quad \|\tilde{x}\|_p = \|\tilde{y}\|_q = 1$$

نُطبق لمّة يونغ (12.5) على $a = \tilde{x}_i$ و $b = \tilde{y}_i$:

$$\tilde{x}_i\,\tilde{y}_i \;\le\; \frac{\tilde{x}_i^{\,p}}{p} + \frac{\tilde{y}_i^{\,q}}{q}$$

ونجمع على $i = 1, \dots, n$:

$$\frac{\sum_i |x_i y_i|}{\|x\|_p \|y\|_q} \;=\; \sum_i \tilde{x}_i \tilde{y}_i \;\le\; \frac{1}{p}\underbrace{\sum_i \tilde{x}_i^{\,p}}_{=\,\|\tilde{x}\|_p^p = 1} + \frac{1}{q}\underbrace{\sum_i \tilde{y}_i^{\,q}}_{=\,\|\tilde{y}\|_q^q = 1} \;=\; \frac{1}{p} + \frac{1}{q} \;=\; 1$$

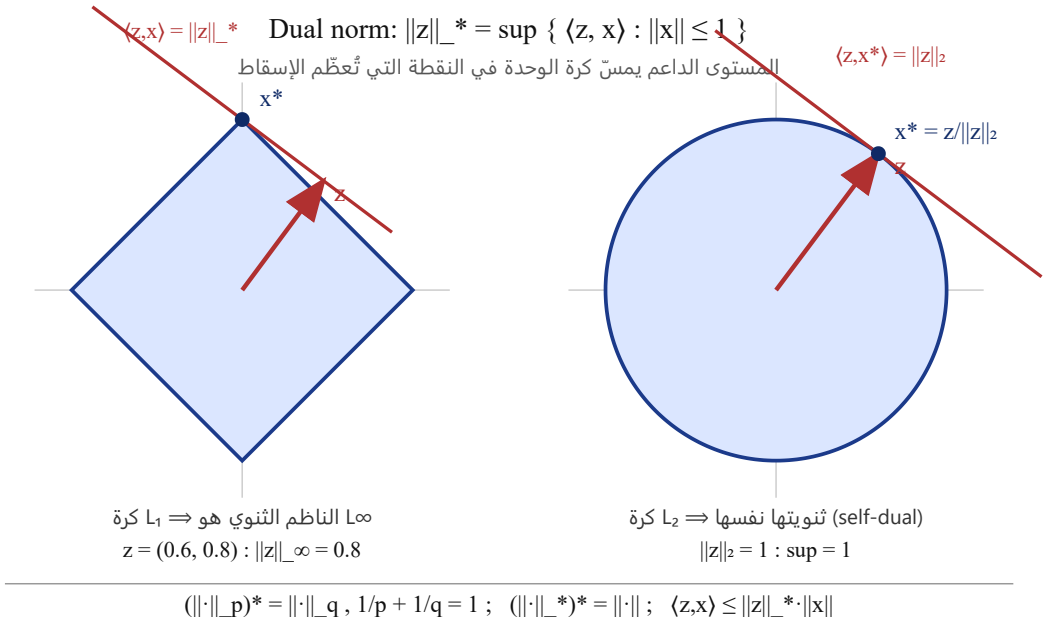
فنحصل على $\sum_i |x_i y_i| \le \|x\|_p \|y\|_q$. والتساوي يتطلّب $\tilde{x}_i^{\,p} = \tilde{y}_i^{\,q}$ لكل i — أي أن الشعاعين $|x|^p$ و $|y|^q$ متناسبان. ■

برهان مينكوفسكي (10.5).

نفصل الحالتين:

الحالة $p = 1$: $|x_i + y_i| \le |x_i| + |y_i|$ (متراجحة المثلث للأعداد الحقيقية)، وبالجمع: $\|x+y\|_1 \le \|x\|_1 + \|y\|_1$.

الحالة $1 < p < \infty$: ليكن q مترافقاً مع p. من متراجحة المثلث العددية ثم هولدر:



شكل ٢.٥: *
الناظم الثنوي: مستوى داعم يمسّ كرة الوحدة

$$\begin{aligned}\|x+y\|_p^p &= \sum_i |x_i+y_i|^p = \sum_i |x_i+y_i|^{p-1}\,|x_i+y_i| \\ &\le \sum_i |x_i+y_i|^{p-1}\big(|x_i|+|y_i|\big) \\ &= \sum_i |x_i+y_i|^{p-1}|x_i| \;+\; \sum_i |x_i+y_i|^{p-1}|y_i| \\ &\le \big\||x+y|^{p-1}\big\|_q\big(\|x\|_p+\|y\|_p\big)\end{aligned}$$

ولأن $(p-1)q = p$ نجد $\big\||x+y|^{p-1}\big\|_q = \big(\sum_i |x_i+y_i|^{(p-1)q}\big)^{1/q} = \|x+y\|_p^{p/q}$. إذن:

$$\|x+y\|_p^p \;\le\; \|x+y\|_p^{p/q}\big(\|x\|_p+\|y\|_p\big)$$

وبالقسمة على $\|x+y\|_p^{p/q}$ (إن كان غيرَ صفر، وإلا فالمتراجحة بديهية) وبملاحظة $p-\frac{p}{q} = p(1-\frac{1}{q}) = p\cdot\frac{1}{p} = 1$:

$$\|x+y\|_p \;\le\; \|x\|_p + \|y\|_p \qquad \blacksquare$$

برهان صيغة الناظم الثنوي (11.5).

من هولدر: $\langle z,x\rangle \le \sum_i |z_i x_i| \le \|z\|_q\|x\|_p$، فـ $\|z\|_* \le \|z\|_q$. ولإثبات العكس نبني متجه الاختبار الذي يحقّق التساوي. ليكن ($1 < p < \infty$ لـ):

$$x_i^\star \;=\; \frac{\operatorname{sgn}(z_i)\,|z_i|^{q-1}}{\|z\|_q^{q-1}}$$

فإن $\|x^\star\|_p = 1$ (تحقّق مباشر: $\sum_i |z_i|^{(q-1)p} = \sum_i |z_i|^q$ لأن $(q-1)p = q$)، و:

$$\langle z,\, x^\star \rangle \;=\; \frac{\sum_i |z_i|^q}{\|z\|_q^{q-1}} \;=\; \|z\|_q$$

إذن $\|z\|_* = \|z\|_q$. وحالة $p=1$: نختار $x^\star = \operatorname{sgn}(z_{i_0})\, e_{i_0}$ عند الإحداثي الأكبر، فنحصل $\|z\|_* = \|z\|_\infty$. وحالة $p=2$: $x^\star = z/\|z\|_2$ فنحصل $\|z\|_* = \|z\|_2$ — أي أن ℓ_2 **ثنوي نفسه** (sefl-dual). ■

3.2.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (5.2-1): تشابه جيب التمام بين تضمينين نصيّين — التحقّق من متراجحة كوشي-شفارتس

المعطيات: تضمينان لجملتين من نموذج لغوي، بُعد التضمين $n = 4$:

$$x = (2,\, -1,\, 3,\, 0)^\top, \qquad y = (1,\, 4,\, -2,\, 1)^\top$$

المطلوب: احسب $\cos\theta$ وتحقّق صراحةً من $|\langle x, y\rangle| \le \|x\|_2 \|y\|_2$، ثم قدر «الفسحة» (slack).

الحل:

١. الضرب الداخلي: $\langle x, y\rangle = 2\cdot 1 + (-1)\cdot 4 + 3\cdot(-2) + 0\cdot 1 = 2 - 4 - 6 + 0 = -8$.

٢. الناظمان: $\|x\|_2 = \sqrt{4+1+9+0} = \sqrt{14} = 3.7417$، و $\|y\|_2 = \sqrt{1+16+4+1} = \sqrt{22} = 4.6904$.

٣. حاصل الضرب (السقف): $\|x\|_2\|y\|_2 = 3.7417 \times 4.6904 = 17.549$.

٤. المتراجحة: $|\langle x, y\rangle| = 8 \le 17.549$ ✓ — والتحقّق ناجح.

٥. جيب التمام: $\cos\theta = -8/17.549 = -0.4559$، والزاوية $\theta = \arccos(-0.4559) \approx 117.1^\circ$.

٦. الفسحة: $\|x\|_2\|y\|_2 - |\langle x, y\rangle| = 17.549 - 8 = 9.549$.

النتيجة: $\cos\theta = -0.4559$ — الجملتان «متباعدتان دلالياً» (زاوية منفرجة)، والفسحة 9.549 تؤكّد أنهما غير متوازيتين.

الربط بالذكاء الاصطناعي: تشابه جيب التمام هو مقياس الاسترجاع الافتراضي في أنظمة RAG والبحث الدلالي. كوشي-شفارتس هي الضمانة الرياضية بأن النتيجة دائماً في $[-1, 1]$، فلا حاجة إلى «قصّ» اصطناعي. كما أن الفسحة تفسّر لماذا يُفضّل تطبيع التضمينات: عندها $\cos\theta = \langle \hat{x}, \hat{y}\rangle$ والترتيب لا يتأثر بأطوال المتجهات.

مثال (5.2-2): تقييد قرابة الانتباه (attention score) والتحجيم بـ $1/\sqrt{d_k}$

المعطيات: في طبقة انتباه، $d_k = 8$، والمتجهان:

$$q = (1.2,\, -0.5,\, 0.8,\, 1.0,\, -0.3,\, 0.6,\, 0.9,\, -1.1)^\top$$
$$k = (0.7,\, 1.1,\, -0.9,\, 0.4,\, 1.3,\, -0.2,\, 0.5,\, 0.8)^\top$$

المطلوب: احسب القرابة الخام $s = q^\top k$ والقرابة المُحَجَّمة $s/\sqrt{d_k}$، وقارن كلتيهما بسقف كوشي–شفارتس.
الحل:

١. القرابة الخام: $s = 0.84 - 0.55 - 0.72 + 0.40 - 0.39 - 0.12 + 0.45 - 0.88 = -0.97$.

٢. الناظمان: $\|q\|_2 = \sqrt{1.44 + 0.25 + 0.64 + 1.00 + 0.09 + 0.36 + 0.81 + 1.21} = \sqrt{5.80} = 2.4083$، و $\|k\|_2 = \sqrt{5.29} = 2.3000$.

٣. السقف قبل التحجيم: $|s| \le 2.4083 \times 2.3000 = 5.539$. والتحقّق: $0.97 \le 5.539$ ✓.

٤. بعد التحجيم: $s/\sqrt{8} = -0.97/2.8284 = -0.3430$، والسقف الجديد $5.539/2.8284 = 1.958$.

٥. لماذا التحجيم؟ إذا كانت مكوّنات q, k مستقلة بتباين 1، فإن $\mathrm{Var}(q^\top k) = d_k = 8$، أي انحراف معياري $\sqrt{8} = 2.83$. القسمة على $\sqrt{d_k}$ تُعيد الانحراف المعياري إلى ≈ 1.

النتيجة: السقف انخفض من 5.539 إلى 1.958، والقرابة نفسها من -0.97 إلى -0.343.
الربط بالذكاء الاصطناعي: هذا بالضبط سبب وجود $\frac{1}{\sqrt{d_k}}$ في صيغة الانتباه المُقنّع (scaled dot-product attention) في «Transformer» بدونه تكبر القرابات مع d_k فتدفع softmax إلى منطقة التشبّع حيث التدرجات شبه صفرية — أي تجمّد التعلّم. كوشي–شفارتس تعطي السقف الأقصى، والتحجيم يضبط **التباين النموذجي** لا السقف.

مثال (2.5-3): متانة نموذج خطي أمام اضطراب ℓ_∞ — هولدر بـ $(p, q) = (1, \infty)$

المعطيات: نموذج خطي $f(x) = w^\top x$ بأوزان $w = (0.4, -1.2, 0.9, -0.3, 0.7)^\top$ ومدخل يتعرّض لاضطراب δ بشرط $\|\delta\|_\infty \le \varepsilon = 0.05$.
المطلوب: أقصى تغيّر ممكن في خرج النموذج، والاضطراب الذي يحقّقه.
الحل:

١. التغيّر في الخرج: $\Delta f = w^\top \delta$ (النموذج خطي).

٢. بهولدر مع $(p, q) = (1, \infty)$: $|\Delta f| \le \|w\|_1 \, \|\delta\|_\infty$.

٣. $\|w\|_1 = 0.4 + 1.2 + 0.9 + 0.3 + 0.7 = 3.5$، فالسقف $= 3.5 \times 0.05 = 0.175$.

٤. الاضطراب الأمثل يحقّق التساوي: $\delta_i^\star = \varepsilon \, \mathrm{sgn}(w_i) = 0.05\,(1, -1, 1, -1, 1)^\top$.

٥. التحقّق: $w^\top \delta^\star = 0.05\,(0.4 + 1.2 + 0.9 + 0.3 + 0.7) = 0.05 \times 3.5 = 0.175$ — **يبلغ السقف تماماً.**

٦. مقارنة بميزانية ℓ_2: لو كان $\|\delta\|_2 \le 0.05$ بدلاً من ذلك، فالسقف $= \|w\|_2 \|\delta\|_2 = \sqrt{2.99} \times 0.05 = 1.7292 \times 0.05 = 0.0865$ — أصغر، لأن كرة ℓ_2 نصف قطرها 0.05 محتواة في كرة ℓ_∞ بالمواصفات نفسها.

النتيجة: تحت $\|\delta\|_\infty \le 0.05$، أقصى تغيّر هو 0.175؛ وتحت $\|\delta\|_2 \le 0.05$ هو 0.0865.
الربط بالذكاء الاصطناعي: هذه هي الحسابات التي تقف خلف هجمات FGSM/PGD وخلف «التدريب الخصمي» (adversarial training). المبدأ العام: **ميزانية الاضطراب تُعيّن الناظم، والناظم الثنوي يُعيّن ما يجب تقليله في الأوزان.** لميزانية ℓ_∞: قلّل $\|w\|_1$ (تناثر). ولميزانية ℓ_2: قلّل $\|w\|_2$ (تنعيم). لهذا يختلف نوع التنظيم باختلاف نموذج التهديد.

مثال (5.2.4): حساب الناظم الثنوي لثلاثة نواظم مختلفة والتحقّق من $(\ell_p)^* = \ell_q$

المعطيات: $z = (3,\, -1,\, 4,\, 0,\, 2)^\top$.

المطلوب: احسب $\|z\|_*$ بالنسبة إلى الناظم الأصلي في الحالات الثلاث ℓ_1، ℓ_2، ℓ_∞، وابحث متجه الاختبار $x^\star$ الذي يحقّق التساوي في كل حالة.

الحل:

١. **الأصل ℓ_∞ ⟸ الثنوي ℓ_1:** $\|z\|_* = \|z\|_1 = 3+1+4+0+2 = 10$. متجه الاختبار: $x^\star = \operatorname{sgn}(z) = (1,\, -1,\, 1,\, 0,\, 1)^\top$. التحقّق: $\|x^\star\|_\infty = 1$ و $\langle z, x^\star\rangle = 3+1+4+0+2 = 10$ ✓.

٢. **الأصل ℓ_1 ⟸ الثنوي ℓ_∞:** $\|z\|_* = \max_i |z_i| = 4$. متجه الاختبار: $x^\star = e_3 = (0,0,1,0,0)^\top$ (وحدة عند الإحداثي الأكبر، بإشارة $+4$ موجبة). التحقّق: $\|x^\star\|_1 = 1$ و $\langle z, x^\star\rangle = 4$ ✓.

٣. **الأصل ℓ_2 ⟸ الثنوي ℓ_2:** $\|z\|_* = \|z\|_2 = \sqrt{9+1+16+0+4} = \sqrt{30} = 5.4772$. متجه الاختبار: $x^\star = z/\|z\|_2 = (0.5477,\, -0.1826,\, 0.7303,\, 0,\, 0.3651)^\top$. التحقّق: $\langle z, x^\star\rangle = \|z\|_2^2/\|z\|_2 = \|z\|_2 = 5.4772$ ✓.

٤. التحقّق من الانعكاسية: $(\|\cdot\|_*)^* = \|\cdot\|$ — فثنوي ℓ_∞ هو ℓ_1، وثنوي ℓ_1 هو ℓ_∞ ✓.

النتيجة: $\|z\|_* = 4$ (أصل ℓ_1)، 5.4772 (أصل ℓ_2)، 10 (أصل ℓ_∞).

الربط بالذكاء الاصطناعي: صيغة الناظم الثنوي هي التي تُنتج **كل** حدود التعميم الشائعة. حدّ «margin» لنموذج خطي تحت اضطراب ℓ_∞ هو $\propto \|w\|_1$؛ وتحت ℓ_2 هو $\propto \|w\|_2$. وصيغة $\|z\| = \max_{\|w\|_*\le 1}\langle z, w\rangle$ هي التي تُستخدم في تحليل Rademacher «complexity» في الجزء السادس (نظرية التعلّم الإحصائي).

مثال (5.2.5): تراكم التدرّجات وقصّها — مينكوفسكي والمتراجحة الفرقية

المعطيات: تدرّجان من دفعتين فرعيّتين (micro-batches): $g_1 = (0.8,\, -1.4,\, 0.3)^\top$ و $g_2 = (-0.5,\, 0.9,\, 1.1)^\top$. ميزانية القصّ $c = 1.0$.

المطلوب: تحقّق من متراجحة المثلث والمتراجحة الفرقية، وقارن «القصّ المشترك» بـ «القصّ لكل دفعة على حدة».

الحل:

١. $\|g_1\|_2 = \sqrt{0.64 + 1.96 + 0.09} = \sqrt{2.69} = 1.6401$؛ و $\|g_2\|_2 = \sqrt{0.25 + 0.81 + 1.21} = \sqrt{2.27} = 1.5067$.

٢. المجموع: $g = g_1 + g_2 = (0.3,\, -0.5,\, 1.4)^\top$؛ $\|g\|_2 = \sqrt{0.09 + 0.25 + 1.96} = \sqrt{2.30} = 1.5166$.

٣. مينكوفسكي: $\|g\|_2 \le \|g_1\|_2 + \|g_2\|_2$، أي $1.5166 \le 1.6401 + 1.5067 = 3.1468$ ✓ — والفسحة كبيرة لأن المتجهين **غير متوازيين**.

٤. المتراجحة الفرقية: $\big|\|g_1\|_2 - \|g_2\|_2\big| = 0.1334 \le \|g_1 - g_2\|_2 = \|(1.3,\, -2.3,\, -0.8)\|_2 = \sqrt{7.62} = 2.7604$ ✓.

٥. القصّ المشترك: معامل القصّ $c/\|g\|_2 = 1.0/1.5166 = 0.6594$، والتحديث المقصوص $0.6594\, g$ = ناظمه 1.0 بالضبط.

٦. القصّ المنفصل: معاملا القصّ $0.6097 = 1.0/1.6401$ و $0.6637 = 1.0/1.5067$. المجموع $g_1 + 0.6637 g_2 = (0.1559,\ -0.2563,\ 0.9130)^\top$، وناظمه $\sqrt{0.9236} = 0.9611$.

النتيجة: القصّ المشترك يعطي تحديثاً ناظمه 1.0 (يستنفد الميزانية ويحفظ الاتجاه)؛ والقصّ المنفصل يعطي 0.9611 (أصغر من اللازم — يفقد معلومة) ويُغيّر الاتجاه.

الربط بالذكاء الاصطناعي: مينكوفسكي تخبرنا أن $\|\sum_k g_k\| \le \sum_k \|g_k\|$ — والحدّ الأيمن **فضفاض جداً** حين تكون التدرّجات متعامدة أو متعاكسة. لهذا تُطبّق مكتبات التدريب الموزّع القصّ على **المجموع العالمي** بعد التجميع (all-reduce)، لا على كل نسخة على حدة: الناظم الحقيقي للمجموع قد يكون أصغر بكثير من مجموع النواظم، وتقديره بالمجموع يبالغ في القصّ.

مثال (5.2-6): الارتباط بين ميزتين مركزيّتين — كوشي–شفارتس في فضاء L^2

المعطيات: ميزتان مقيسَتان على $n = 5$ عيّنات، ومُمركَزتان (متوسط كل منهما صفر):

$$x_1 = (1.2,\ -0.8,\ 0.3,\ -1.5,\ 0.8)^\top, \qquad x_2 = (0.9,\ -1.1,\ 0.5,\ -0.7,\ 0.4)^\top$$

المطلوب: احسب معامل الارتباط (correlation) وتحقّق أنه في $[-1, 1]$ بفعل كوشي–شفارتس.

الحل:

١. التحقّق من التمركز: $\bar{x}_1 = (1.2 - 0.8 + 0.3 - 1.5 + 0.8)/5 = 0$ ✓، $\bar{x}_2 = (0.9 - 1.1 + 0.5 - 0.7 + 0.4)/5 = 0$ ✓.

٢. الضرب الداخلي: $\langle x_1, x_2 \rangle = 1.08 + 0.88 + 0.15 + 1.05 + 0.32 = 3.48$.

٣. الناظمان: $\|x_1\|_2 = \sqrt{1.44 + 0.64 + 0.09 + 2.25 + 0.64} = \sqrt{5.06} = 2.2494$؛ $\|x_2\|_2 = \sqrt{0.81 + 1.21 + 0.25 + 0.49 + 0.16} = \sqrt{2.92} = 1.7088$.

٤. الارتباط: $\rho = \dfrac{\langle x_1, x_2 \rangle}{\|x_1\|_2 \|x_2\|_2} = \dfrac{3.48}{2.2494 \times 1.7088} = \dfrac{3.48}{3.8436} = 0.9054$.

٥. كوشي–شفارتس: $|3.48| \le 3.8436$ ✓، و $|\rho| = 0.9054 \le 1$ ✓.

النتيجة: $\rho = 0.9054$ — الميزتان مرتبطتان ارتباطاً إيجابياً قوياً، ولولا كوشي–شفارتس لما كان مضموناً أن يقع الارتباط في $[-1, 1]$.

الربط بالذكاء الاصطناعي: الارتباط هو كوشي–شفارتس **مطبّقاً على فضاء المتغيّرات العشوائية** L^2 مع الضرب الداخلي $\langle X, Y \rangle = \mathbb{E}[XY]$. هذه القراءة نفسها تعطي: $|\mathrm{Cov}(X, Y)| \le \sigma_X \sigma_Y$، وكل حدود التباين في تعلّم التعزيز (مثل تحليل تباين مقدّر السياسة) هي كوشي–شفارتس متخفّية.

مثال (5.2-7): العلاقة الدقيقة بين مسافة ℓ_2 وتشابه جيب التمام على تضمينات مُطبَّعة

المعطيات: تضمينان مُطبَّعان $\|\hat{x}\|_2 = \|\hat{y}\|_2 = 1$، وتشابههما $\cos\theta = 0.85$.
المطلوب: احسب $\|\hat{x} - \hat{y}\|_2$ من التشابه مباشرةً، وتحقّق بالمثال الصريح.
الحل:

١. بتوسيع المربع: $\|\hat{x} - \hat{y}\|_2^2 = \|\hat{x}\|_2^2 + \|\hat{y}\|_2^2 - 2\langle \hat{x}, \hat{y} \rangle$.

٢. بما أن الطولين $= 1$ و $\langle \hat{x}, \hat{y} \rangle = \cos\theta$:

$$\|\hat{x} - \hat{y}\|_2^2 \;=\; 1 + 1 - 2\cos\theta \;=\; 2(1 - \cos\theta)$$

٣. بالتعويض: $\|\hat{x} - \hat{y}\|_2 = \sqrt{2(1 - 0.85)} = \sqrt{0.30} = 0.5477$.

٤. تحقّق صريح: ليكن $\hat{x} = (1, 0)^\top$ و $\hat{y} = (0.85,\, 0.5268)^\top$ (حيث $0.5268 = \sqrt{1 - 0.85^2}$ $= \sqrt{0.2775}$). إذن $\|\hat{x} - \hat{y}\|_2^2 = (1 - 0.85)^2 + (0 - 0.5268)^2 = 0.0225 + 0.2775 = 0.3000$ ✓، فالمسافة $= 0.5477$ ✓.

النتيجة: على المتجهات المُطبَّعة: $\|\hat{x} - \hat{y}\|_2 = \sqrt{2(1 - \cos\theta)}$ — ترتيب المسافة الإقليدية **مطابق تماماً** لترتيب التشابه (لأن الجذر تابع monotonically increasing).

الربط بالذكاء الاصطناعي: هذه المتطابقة تفسّر لماذا لا فرق عملياً بين «أقرب الجيران بالمسافة الإقليدية» و«الأعلى تشابهاً» على تضمينات مُطبَّعة — وهو ما تفعله قواعد بيانات المتجهات (FAISS، Annoy) وتفسّر أيضاً لماذا تُطبَّع التضمينات قبل الفهرسة: التطبيع يُلغي أثر أطوال المتجهات ويجعل الناظمَين متكافئين ترتيبياً.

مثال (8-2.5): فحص صلاحية مصفوفة نواة (Gram) بمتراجحة كوشي–شفارتس

المعطيات: مصفوفة نواة مقترحة على ثلاث عيّنات:

$$K = \begin{pmatrix} 4 & 2.9 & 1.1 \\ 2.9 & 2.25 & 0.8 \\ 1.1 & 0.8 & 0.36 \end{pmatrix}$$

المطلوب: تحقّق من شرط كوشي–شفارتس $|K_{ij}| \;\le\; \sqrt{K_{ii}K_{jj}}$ لكل زوج، ثم من كون K موجبة التحديد، وقدّر حالة التكييف (conditioning).
الحل:

١. الزوج $(1,2)$: $|2.9| \le \sqrt{4 \times 2.25} = \sqrt{9} = 3$ ✓ — شبه مُحكم.

٢. الزوج $(1,3)$: $|1.1| \le \sqrt{4 \times 0.36} = \sqrt{1.44} = 1.2$ ✓.

٣. الزوج $(2,3)$: $|0.8| \le \sqrt{2.25 \times 0.36} = \sqrt{0.81} = 0.9$ ✓.

٤. شرط كوشي–شفارتس **ضروري ولا يكفي**؛ نتحقّق من المُنَّات الرائدة لـ Sylvester: $4 > 0$، و $4 \times 2.25 - 2.9^2 = 9 - 8.41 = 0.59 > 0$، و $\det K = 4(0.81 - 0.64) - 2.9(1.044 - 0.88) + 1.1(2.32 - 2.475) = 0.68 - 0.4756 - 0.1705 = 0.0339 > 0$. إذن $K \succ 0$ ✓.

٥. كثير الحدود المميِّز: $\operatorname{tr} K = 6.61$، ومجموع المُنَّات الرائدة $2 \times 2 \; 0.99 = 0.59 + 0.23 + 0.17 =$، فـ $\lambda^3 - 6.61\lambda^2 + 0.99\lambda - 0.0339 = 0$، وجذوره $\lambda \approx (6.456,\ 0.103,\ 0.051)$.

٦. حالة التكييف: $\kappa = \lambda_{\max}/\lambda_{\min} \approx 6.456/0.051 \approx 127$.

النتيجة: المصفوفة نواة صالحة، لكنها **سيّئة التكييف** ($\kappa \approx 127$) لأن الزوج $(1, 2)$ شبه متوازٍ.

الربط بالذكاء الاصطناعي: في ridge SVM/kernel regression، مخالفة $|K_{ij}| \le \sqrt{K_{ii}K_{jj}}$ تكشف فوراً نواة غير صالحة (خطأ في التنفيذ أو في المقياس). والتقارب الشديد من حدّ كوشي–شفارتس **إنذار مبكر بسوء التكييف** قبل حساب أي قيمة ذاتية: سينهار حلّ الانحدار أو سيتطلّب تنظيماً كبيراً. القاعدة العملية: راقب $\max_{i \neq j} |K_{ij}| / \sqrt{K_{ii}K_{jj}}$؛ كلما اقترب من 1 اقتربت المصفوفة من الانفراد.

مثال (٥.٢-9): ثلاث ميزانيات اضطراب وثلاثة نواظم ثنوية — جدول المتانة الكامل

المعطيات: نموذج خطي بأوزان $w = (6,\ -8,\ 3,\ 9)^{\top}$، وميزانية اضطراب $\varepsilon = 0.1$ تُقاس بثالثة نواظم مختلفة.

المطلوب: أقصى تغيّر في الخرج $|\Delta f| \le \varepsilon \|w\|_*$ لكل ميزانية، والاضطراب الأمثل في كل حالة.

الحل:

١. النواظم الأساسية: $\|w\|_1 = 6 + 8 + 3 + 9 = 26$؛ $\|w\|_2 = \sqrt{36 + 64 + 9 + 81} = \sqrt{190} = 13.784$؛ $\|w\|_\infty = 9$.

٢. **ميزانية ℓ_2** $\Longrightarrow$ الثنوي ℓ_2: $|\Delta f| \le 0.1 \times 13.784 = 1.378$، ويحقَّق بـ $\delta^\star = 0.1\, w/\|w\|_2$.

٣. **ميزانية ℓ_1** $\Longrightarrow$ الثنوي ℓ_∞: $|\Delta f| \le 0.1 \times 26 = 2.60$، ويحقَّق بـ $\delta^\star = 0.1 \operatorname{sgn}(w) = (0.1,\ -0.1,\ 0.1,\ 0.1)^{\top}$.

٤. **ميزانية ℓ_∞** $\Longrightarrow$ الثنوي ℓ_1: $|\Delta f| \le 0.1 \times 9 = 0.90$، ويحقَّق بـ $\delta^\star = 0.1\, e_4$ (الإحداثي ذو أكبر $|w_i|$).

٥. الترتيب: $0.90 < 1.378 < 2.60$ — وهو ترتيب **احتواء الكرات**: $B_1(0.1) \subset B_2(0.1) \subset B_\infty(0.1)$ على $\mathbb{R}^4$.

النتيجة: أخطر ميزانية هي ℓ_∞ (تغيّر 2.60) وأضعفها ℓ_1 (تغيّر 0.90).

الربط بالذكاء الاصطناعي: هذا الجدول هو «خريطة التهديد» الكاملة لتقييم المتانة. الميزانية ℓ_∞ هي المعيار في رؤية الحاسوب (تغيّر كل بكسل قليلاً لا يُرى بالعين لكنه يقلب القرار). والميزانية ℓ_1 تناسب «تعديل عدد محدود من الكلمات». اختيار الميزانية ليس تفصيلاً تقنياً: **الميزانيةُ تحدّد الناظم الثنوي، والثنوي يحدّد التنظيم الذي يقي فعلاً.**

مثال (٥.٢-10): هولدر بأُسّين غير مألوفين $(p, q) = (4, \frac{4}{3})$ على التدرّج وزخمه

المعطيات: تدرّج $g = (0.5,\ -2.0,\ 1.5,\ -0.25,\ 3.0)^{\top}$ ومتجه زخم ثانٍ غير سالب $v = (0.1,\ 0.4,\ 0.25,\ 0.05,\ 0.6)^{\top}$.

المطلوب: تحقّق من هولدر $\sum_i |g_i v_i| \le \|g\|_4 \, \|v\|_{4/3}$ رقمياً، وقارن بكوشي–شفارتس $(p, q) = (2, 2)$.

الحل:

١. $\frac{1}{4}+\frac{1}{q}=1\Rightarrow q=\frac{4}{3}$ ✓ (ترافق).

٢. $\|g\|_4=\left(0.5^4+2^4+1.5^4+0.25^4+3^4\right)^{1/4}=\left(0.0625+16+5.0625+0.0039+81\right)^{1/4}=(102.129)^{1/4}=3.179$.

٣. $v_i^{4/3}=(0.0464,\ 0.2947,\ 0.1575,\ 0.0184,\ 0.5060)$، حيث $\|v\|_{4/3}=\left(\sum_i v_i^{4/3}\right)^{3/4}$، مجموعها 1.0231؛ إذن $\|v\|_{4/3}=(1.0231)^{0.75}=1.0173$.

٤. سقف هولدر: $3.179\times 1.0173=3.234$.

٥. القيمة الفعلية: $\sum_i|g_iv_i|=0.05+0.80+0.375+0.0125+1.80=3.0375\le 3.234$ ✓.

٦. مقارنة بـ $(2,2)$: $\|g\|_2=\sqrt{0.25+4+2.25+0.0625+9}=\sqrt{15.5625}=3.9449$؛ $\|v\|_2=\sqrt{0.01+0.16+0.0625+0.0025+0.36}=\sqrt{0.595}=0.7714$، السقف $=3.0433$ — وهو **أحكم** قليلاً من 3.234 هنا.

النتيجة: كلا السقفين صحيح: $3.0375\le 3.0433$ (كوشي-شفارتس) و $3.0375\le 3.234$ (هولدر بـ $(4,\frac{4}{3})$). أيهما أحكم يعتمد على شكل المتجهين.

الربط بالذكاء الاصطناعي: لا يوجد زوج «أفضل دائماً»؛ **تختار الأُسّين بحسب ما تعرفه عن المتجهين.** إذا كان لأحدهما ذيل ثقيل (قيم قليلة كبيرة جداً — كما في تدرّجات الطبقات العميقة أو نسب الأهمية في تعلّم السياسات خارج السياسة)، فالأُسّ الأكبر p يلتقط الذيل؛ وإذا كان الآخر مسطحاً فالأُسّ الأصغر يكفي. مرونة هولدر هي بالضبط ما يجعل حدود التعميم قابلة للتكييف مع توزيع الأخطاء.

مثال (2.5-11): دمج نماذج مضبوطة دقيقاً (task vectors) — متى تكون مينكوفسكي فضفاضة؟

المعطيات: متجهان للمهام (فروق أوزان بعد الضبط الدقيق): $\tau_1=(0.30,\ -0.12,\ 0.45,\ 0.08)^\top$ و $\tau_2=(-0.18,\ 0.33,\ 0.10,\ -0.25)^\top$.

المطلوب: احسب ناظم المجموع المدمج، وتحقّق من مينكوفسكي، وفسّر الفسحة بالتشابه بين المتجهين.

الحل:

١. $\|\tau_1\|_2=\sqrt{0.09+0.0144+0.2025+0.0064}=\sqrt{0.3133}=0.5597$؛ $\|\tau_2\|_2=\sqrt{0.0324+0.1089+0.01+0.0625}=\sqrt{0.2138}=0.4624$.

٢. المجموع: $\tau=(0.12,\ 0.21,\ 0.55,\ -0.17)^\top$؛ $\|\tau\|_2=\sqrt{0.0144+0.0441+0.3025+0.0289}=\sqrt{0.3899}=0.6244$.

٣. مينكوفسكي: $0.6244\le 0.5597+0.4624=1.0221$ ✓؛ الفسحة $=0.3977$ — كبيرة جداً.

٤. التفسير: $\langle\tau_1,\tau_2\rangle=-0.054-0.0396+0.045-0.02=-0.0686$؛ $\cos\theta=-0.0686/(0.5597\times 0.4624)=-0.0686/0.2588=-0.2651$.

٥. تحقّق بالمتطابقة: $\|\tau_1+\tau_2\|_2^2=0.3133+0.2138+2(-0.0686)=0.3899$ ✓ — التداخل **سالب**، فالمجموع أقصر مما تتوقّع مينكوفسكي.

٦. الدمج المُقاس: $\|\frac{1}{2}\tau\|_2 = 0.3122$.

النتيجة: الدمج يعطي ناظماً 0.6244 بدلاً من السقف 1.0221، لأن المهام متعارضة جزئياً ($\cos\theta = -0.265$).
الربط بالذكاء الاصطناعي: دمج النماذج (model arithmetic) task / merging يعتمد على هذه الحساب بالضبط. إذا كان $\cos(\tau_1, \tau_2) < 0$ فالدمج **يُضعف** كلا المتجهين (تداخل هدّام)؛ وإذا كان $1 \approx$ فينكوفسكي شبه مُحكمة والدمج يجمع الطولين. لذلك تُقاس «زاوية المهمة» قبل الدمج، وتُستخدم خوارزميات مثل TIES/DARE لإزالة المكوّنات المتعارضة إحداثياً قبل الجمع.

مثال (5.2-12): الفحص الآمن (safe screening) في Lasso — الناظم الثنوي يُلغي الحل كله

المعطيات: مصفوفة تصميم X بأعمدة $x_1 = (1.2, -0.6, 0.3)^\top$، $x_2 = (1.6, 1.2, 0.8)^\top$، $x_3 = (0.5, -0.4, 0.6)^\top$؛ ومتبقٍّ $r = (0.5, -0.3, 0.2)^\top$؛ ومعامل تنظيم $\lambda = 1.5$.
المطلوب: قرّر — بدون تشغيل محلّل Lasso — هل الحل متجه الأصفار.
الحل:

١. شرط KKT ليكون $w = 0$ حلاً: $\|X^\top r\|_\infty \le \lambda$.

٢. ناظم الأعمدة: $\|x_1\|_2 = \sqrt{1.44 + 0.36 + 0.09} = \sqrt{1.89} = 1.3748$؛ $\|x_2\|_2 = \sqrt{2.56 + 1.44 + 0.64} = \sqrt{4.64} = 2.1541$؛ $\|x_3\|_2 = \sqrt{0.25 + 0.16 + 0.36} = \sqrt{0.77} = 0.8775$.

٣. $\|r\|_2 = \sqrt{0.25 + 0.09 + 0.04} = \sqrt{0.38} = 0.6164$.

٤. ب كوشي–شفارتس لكل عمود: $|x_j^\top r| \le \|x_j\|_2\|r\|_2$، فأعلى سقف ممكن $= 2.1541 \times 0.6164 = 1.3274$.

٥. بما أن $\lambda = 1.5 > 1.3274$، فـ $\|X^\top r\|_\infty \le 1.3274 < 1.5$ **مضمون قبل أي حساب للضروب الداخلية** $\Longrightarrow$ الحل هو $w = 0$.

٦. تحقّق مباشر: $x_1^\top r = 0.6 + 0.18 + 0.06 = 0.84$؛ $x_2^\top r = 0.8 - 0.36 + 0.16 = 0.60$؛ $x_3^\top r = 0.25 + 0.12 + 0.12 = 0.49$؛ فـ $\|X^\top r\|_\infty = 0.84 \le 1.3274 \le 1.5$. ✓

النتيجة: الحل هو الصفر، وتم إثبات ذلك بحدّ ناظمي رخيص (ثلاثة ناظمات أعمدة وناظم متبقٍّ) بدلاً من تشغيل محلّل كامل.
الربط بالذكاء الاصطناعي: هذه هي فكرة **الفحص الآمن** (safe screening / SAFE rules) في المسائل المتناثرة: نستخدم متراجحة الناظم الثنوي لنتخلّص من أعمدة أو من المسألة كلها قبل بدء التحسين. في مسائل بآلاف الميزات و«مسار تنظيم» (regularization path) كامل، يوفّر هذا أضعافاً مضاعفة من الوقت — والضمانة رياضية صارمة، لا تجريبية.

مثال (5.2-13): الناظم الثنوي للناظم المختلط $\ell_{2,1}$ (Group Lasso)

المعطيات: متجه أوزان $w \in \mathbb{R}^6$ مقسّم إلى ثلاث مجموعات من إحداثيين: $g_1 = (3, -4)$، $g_2 = (1, 1)$، $g_3 = (0, -2)$.

المطلوب: احسب $\|w\|_{2,1}$ و $\|w\|_{2,\infty}$، وتحقّق من الازدواج $(\ell_{2,1})^* = \ell_{2,\infty}$ عملياً.

الحل:

١. التعريف: $\|w\|_{2,1} = \sum_g \|w_g\|_2$ (ناظم ℓ_1 على ناظمات ℓ_2 للمجموعات)؛ و $\|w\|_{2,\infty} = \max_g \|w_g\|_2$.

٢. ناظمات المجموعات: $\|g_1\|_2 = \sqrt{9+16} = 5$؛ $\|g_2\|_2 = \sqrt{1+1} = 1.4142$؛ $\|g_3\|_2 = \sqrt{0+4} = 2$.

٣. $\|w\|_{2,1} = 5 + 1.4142 + 2 = 8.4142$؛ و $\|w\|_{2,\infty} = 5$.

٤. المتراجحة المعمّمة: $\langle w, w\rangle = \|w\|_2^2 = 25 + 2 + 4 = 31 \le \|w\|_{2,1}\,\|w\|_{2,\infty} = 8.4142 \times 5 = 42.07$ ✓.

٥. متجه الاختبار المُحقّق للتساوي: $z_g = w_g / \|w_g\|_2$ لكل مجموعة، أي $z = \big(0.6,\ -0.8,\ 0.7071,\ 0.7071,\ 0,\ -1\big)^\top$. عندها $\|z\|_{2,\infty} = \max(1,1,1) = 1$ ✓ و $\langle z, w\rangle = 5 + 1.4142 + 2 = 8.4142 = \|w\|_{2,1}$ ✓.

النتيجة: $(\ell_{2,1})^* = \ell_{2,\infty}$ مؤكَّد رقمياً: السقف 42.07 والقيمة المُعظَّمة 8.4142 مع $\|z\|_{2,\infty} = 1$.

الربط بالذكاء الاصطناعي: تنظيم Group-Lasso $(\ell_{2,1})$ هو الذي يختار **مجموعات كاملة من الميزات** (مثل قنوات الالتفاف، أو مجموعات المتغيّرات الوهمية لمتغيّر فئوي) لا إحداثيات مفردة. معرفة ثنويه ضرورية لاشتقاق شرط KKT وخوارزميات الإحداثيات النزولية ولحدود التعميم. القاعدة العامة: **ثنوي ناظم «مجموع على مجموعات من ناظم داخلي» هو «أقصى على مجموعات من الثنوي الداخلي».**

مثال (5.2-14): هولدر في فضاء الاحتمالات — تقدير خارج السياسة (off-policy) بنسب الأهمية

المعطيات: أربع عيّنات باحتمال متساوٍ $\frac{1}{4}$. نسب الأهمية $\rho = (1.5,\ 3.0,\ 0.2,\ 0.8)$ ومقادير الخسارة $|\ell| = (0.4,\ 1.2,\ 0.0,\ 2.1)$. استخدم $(p, q) = (3, \frac{3}{2})$.

المطلوب: احسب $\mathbb{E}|\rho\ell|$ فعلياً، وقارنه بسقف هولدر $\|\rho\|_3\,\|\ell\|_{3/2}$.

الحل:

١. الترافق: $\frac{1}{3} + \frac{1}{q} = 1 \Rightarrow q = \frac{3}{2}$ ✓.

٢. القيمة الفعلية: $\mathbb{E}|\rho\ell| = \frac{1}{4}\big(1.5\times0.4 + 3.0\times1.2 + 0.2\times0 + 0.8\times2.1\big) = \frac{1}{4}(0.6 + 3.6 + 0 + 1.68) = \frac{1}{4}(5.88) = 1.47$.

٣. $\|\rho\|_3 = \big(\mathbb{E}\rho^3\big)^{1/3} = \big[\frac{1}{4}(3.375 + 27 + 0.008 + 0.512)\big]^{1/3} = (7.7238)^{1/3} = 1.9766$.

٤. $\|\ell\|_{3/2}$: المقادير $|\ell|^{3/2} = (0.2530,\ 1.3145,\ 0,\ 3.0432)$، المتوسط $\mathbb{E}|\ell|^{3/2} = 1.1527$؛ إذن $\|\ell\|_{3/2} = \big(\mathbb{E}|\ell|^{3/2}\big)^{2/3} = (1.1527)^{2/3} = 1.0994$.

٥. سقف هولدر: $1.47 \geq 2.1731 = 1.0994 \times 1.9766$ ✓.

النتيجة: $\mathbb{E}|\rho\ell| = 1.47 \leq 2.1731$، والسقف صالح وإن كان فضفاضاً بمعامل ≈ 1.48.

الربط بالذكاء الاصطناعي: نسب الأهمية في تعلّم التعزيز خارج السياسة لها ذيول ثقيلة: قد لا يكون لـ ρ عزم ثانٍ، وقد لا تنطبق كوشي–شفارتس عملياً (الحدّ قد يكون لانهائياً). ميزة هولدر أنها **تتيح اختيار الأُسّ بحسب العزم الموجود فعلاً**: استخدم p أكبر إذا كان ذيل ρ ثقيلاً، عندئذ يقترب q من 1 ويخفّ العبء على ℓ. هذه هي الفكرة خلف مقاييس «وزنات الأهمية المقصوصة» و«مقدّرات العزم المُقصّ».

مثال (15-2.5): كشف انهيار التمثيل (representation collapse) من شرط التساوي في كوشي–شفارتس

المعطيات: ثلاثة متجهات خرج من طبقة تضمين مدمجة: $u = (1.5, -2.0, 0.5)^\top$، و $v = (-3.0, 4.0, -1.0)^\top$، و $w = (1.5, -2.0, 0.6)^\top$.

المطلوب: استخدم **فسحة** كوشي–شفارتس $\delta = \|x\|_2\|y\|_2 - |\langle x, y\rangle|$ كمؤشّر لانهيار التمثيل، وقيّم الأزواج الثلاثة.

الحل:

١. $\|u\|_2 = \sqrt{2.25 + 4 + 0.25} = \sqrt{6.5} = 2.5495$.

٢. الزوج (u, v): لاحظ $v = -2u$ تماماً، فـ $\|v\|_2 = 5.0990$ و $\langle u, v\rangle = -13.0$؛ والسقف $= 2.5495 \times 5.0990 = 13.0$. الفسحة $\delta = 13.0 - 13.0 = 0$ $\Longrightarrow$ **تساوي تام** $\Longrightarrow$ تبعية خطية $\Longrightarrow$ انهيار كامل. و $\cos\theta = -1$.

٣. الزوج (u, w): $\|w\|_2 = \sqrt{2.25 + 4 + 0.36} = \sqrt{6.61} = 2.5709$؛ $\langle u, w\rangle = 2.25 + 4 + 0.30 = 6.55$، السقف $= 2.5495 \times 2.5709 = 6.5545$. الفسحة $\delta = 6.5545 - 6.55 = 0.0045$، و $\cos\theta = 6.55/6.5545 = 0.99931$. مؤشّر الانهيار $1 - |\cos\theta| = 0.00069$ $\Longrightarrow$ **شبه انهيار**.

٤. الزوج (v, w): $\langle v, w\rangle = -4.5 - 8 - 0.6 = -13.1$؛ السقف $= 5.0990 \times 2.5709 = 13.109$؛ الفسحة $= 0.009$ $\Longrightarrow$ شبه انهيار أيضاً (متوقّع: كلاهما قريب من u).

النتيجة: الفسحة تعمل مؤشّراً حسّاساً: $\delta = 0$ للزوج المتوازي تماماً، و $\delta \approx 0.0045$ للزوج شبه المتوازي.

الربط بالذكاء الاصطناعي: في التعلّم المتناقض (contrastive learning) والتعلّم الذاتي الإشراف (SimCLR، BYOL، VICReg) أخطر وضع فشل هو **الانهيار** — كل التضمينات تصبح متوازية أو ثابتة. مؤشّر التشخيص المستعمل عملياً (مثل فقدان التباين في VICReg) هو في جوهره قياس **بُعد** المتجهات عن شرط التساوي في كوشي–شفارتس. القاعدة: راقب $\min_{i \neq j}(1 - |\cos\theta_{ij}|)$ عبر الدفعة؛ انحداره إلى الصفر يعني الانهيار.

4.2.5 أخطاء شائعة في تطبيق متراجحات كوشي–شفارتس وهولدر

الخطأ الشائع	لماذا هو خطأ؟	التصحيح
تطبيق $\|x\|_p = (\sum \|x_i\|^p)^{1/p}$ مع $p < 1$	متراجحة المثلث تفشل، فلا يوجد ناظم	اطلب $p \geq 1$ دائماً، و$p < 1$ يُستخدم كـ «بديل مقعّب» فقط
$\|\langle x, y\rangle\| \leq \|x\|_1 \|y$ أصحّ من كوشي–شفارتس	صحيح لكنه أضعف: $\|x\|_1 \geq \|x\|_2$	استخدم الناظمين **المترافقين**: ℓ_2 مع ℓ_2، أو ℓ_1 مع ℓ_∞
نسيان شرط التوافق $\frac{1}{p} + \frac{1}{q} = 1$	المتراجحة باطلة بلا هذا الشرط	احسب $q = p/(p-1)$ دائماً قبل الاستخدام
الخلط بين $\|\cdot\|_*$ والناظم الإقليدي	الثنوي يعتمد على الناظم الأصلي: $(\ell_1)^* = \ell_\infty$ لا ℓ_2	عيّن الناظم الأصلي أولاً، ثم ثنويه
$\|x + y\| \leq \|x$ لتقدير نمو الخطأ واعتباره محكماً	الحدّ فضفاض حين يكون المتجهان متعاكسين	احسب الزاوية؛ استخدم المتطابقة $\|x+y\|^2 = \|x\|^2 + \|y\|^2 + 2\langle x, y\rangle$
شي–شفارتس على مصفوفة النواة **كافٍ** لصلاحيتها	هو ضروري فقط	تحقّق من موجبية التحديد (Sylvester) أو القيم الذاتية
تجاهل شرط $x \neq 0$ عند حساب الزاوية	القسمة على $\|x\|_2 = 0$ غير معرّفة	تحقّق من $\|x\|_2 > \varepsilon$ قبل حساب arccos
قصّ التدرّج لكل دفعة فرعية بدل المجموع	يُغيّر الاتجاه ويقلّل الناظم دون داعٍ	اجمع أولاً، ثم اقصّ مرة واحدة
افتراض أن sup في تعريف الثنوي لا يُحقَّق	كرة الوحدة متراصّة والشكل خطّي $\Longrightarrow$ يتحقّق كـ max	استخدم $\max_{\|x\|=1}$ وابحث عن $x^\star$ صريحاً
$\|z\| \leq \|\langle z, x\rangle\|$ وبين $\|\langle z, x\rangle\| \leq \|z\| \|x\|_*$	النجمة على الناظم **الثنوي** فقط؛ الترتيب مهم لكنه متناظر هنا	اكتب: الناظم الثنوي يقابل الناظم الأصلي، ولا تضع النجمة على الاثنين

الفكرة في سطر: على فضاء **منتهي البعد**، كل النواظم متكافئة: لا يوجد ناظم «أصحّ» من آخر من حيث التقارب أو الاتصال أو الاستمرارية. لكن **ثوابت التحويل** بينها تعتمد على البعد n — وهذه الثوابت بالذات هي التي تصنع الفرق بين حدّ تعميم مفيد وحدّ تعميم فارغ. في الأبعاد اللانهائية (الدوال، الشبكات العصبية كعناصر في فضاء دالي) **يفشل** التكافؤ، وهناك تكمن معظم صعوبات النظرية.

1.3.5 الصياغة الرسمية

نظرية (رتابة نواظم ℓ_p وحدود التحويل بينها).

ليكن $x \in \mathbb{R}^n$ و $1 \leq p \leq q \leq \infty$. عندئذٍ:

$$\|x\|_q \;\leq\; \|x\|_p \;\leq\; n^{\frac{1}{p}-\frac{1}{q}}\, \|x\|_q \tag{13.5}$$

والحدّان **محكمان** (لا يمكن تحسينهما): الأسفل يتحقّق للمتجهات وحيدة الإحداثي $x = e_i$، والأعلى للمتجهات متساوية الإحداثيات $x = \mathbf{1}$.

جدول رموز (13.5):

الرمز	المعنى	ملاحظات
p	الأُسّ الأصغر	$1 \leq p \leq q$
q	الأُسّ الأكبر	قد يكون ∞
$\|x\|_q$	الناظم بالأُسّ الأكبر	**أصغر** قيمة: الطرف الأيسر
$\|x\|_p$	الناظم بالأُسّ الأصغر	أكبر قيمة
n	بُعد الفضاء	مصدر اعتماد الثابت على البعد
$n^{1/p-1/q}$	ثابت التحويل العلوي	$\sqrt{n}$: $p=2, q=\infty$؛ $\sqrt{n}$: $p=1, q=2$؛ n: $p=1, q=\infty$
e_i	متجه الوحدة في الإحداثي i	يجعل الحدّ الأسفل مُحكَماً: كل النواظم $= 1$
$\mathbf{1}$	متجه كل إحداثياته 1	يجعل الحدّ الأعلى مُحكَماً: $\|\mathbf{1}\|_p = n^{1/p}$
«محكم» (sharp) / tight)	الثابت لا يمكن تصغيره	يثبت أن الاعتماد على n حقيقي لا صناعي

نظرية (التكافؤ العام).

ليكن $\|\cdot\|_\alpha$ و $\|\cdot\|_\beta$ ناظمين أيّين على فضاء متجهي منتهي البعد V ببعد n. عندئذٍ يوجد ثابتان $c, C > 0$ بحيث لكل $x \in V$:

$$c\,\|x\|_\alpha \;\le\; \|x\|_\beta \;\le\; C\,\|x\|_\alpha \tag{14.5}$$

وأفضل (أصغر) ثابت أعلى وأكبر ثابت أسفل هما:

$$C_{\alpha\to\beta} \;=\; \max_{\|x\|_\alpha=1} \|x\|_\beta, \qquad c_{\alpha\to\beta} \;=\; \min_{\|x\|_\alpha=1} \|x\|_\beta \;=\; \frac{1}{C_{\beta\to\alpha}} \tag{15.5}$$

جدول رموز (14.5)–(15.5):

الرمز	المعنى	ملاحظات
$\|\cdot\|_\alpha,\ \|\cdot\|_\beta$	ناظمان أيّان على V	قد يكونان ℓ_q/ℓ_p، أو ناظمين مصفوفيّين، أو ناظمين «مركّبين»
c	ثابت التحويل السفلي (أكبر قيمة ممكنة له)	$c > 0$ دائماً في الأبعاد المنتهية
C	ثابت التحويل العلوي (أصغر قيمة ممكنة له)	$C < \infty$ دائماً في الأبعاد المنتهية
V	فضاء متجهي **منتهي البعد**	الشرط جوهري: في الأبعاد اللانهائية يفشل التكافؤ
$n = \dim V$	بُعد الفضاء	يظهر في c و C الفعليين
$\max_{\|x\|_\alpha=1}$	التعظيم على **سطح** كرة الوحدة الأولى	يعطي «أقصى تمدّد» للناظم الثاني
$\min_{\|x\|_\alpha=1}$	التصغير على السطح نفسه	يعطي «أدنى تمدّد»
$C_{\alpha\to\beta}$	الثابت الأمثل للاتجاه $\alpha \to \beta$	الرمز ذو السهم يوضّح الاتجاه
$1/C_{\beta\to\alpha}$	العلاقة الانعكاسية بين الثابتين	توفّر حسابَ نصفِ الثوابت

مسلّمة التراصّ (حجر أساس البرهان):

$$S_\alpha \;=\; \{\, x \in V : \|x\|_\alpha = 1 \,\} \text{ (compact) متراصّة}, \qquad x \mapsto \|x\|_\beta \text{ متصلة وموجبة تماماً على } S_\alpha \tag{16.5}$$

نتيجة (التنقية بالتناثر — sparse refinement). ليكن x متناثراً بـ s إحداثي غير صفري ($|\operatorname{supp}(x)| \;=\; s$)، و $1 \le q \le p$. عندئذٍ الوعاء الفعّال للبعد هو s لا n:

$$\|x\|_1 \;\le\; \sqrt{s}\,\|x\|_2 \qquad \text{وخاصةً} \qquad \|x\|_p \;\le\; s^{\frac{1}{q}-\frac{1}{p}}\,\|x\|_q, \tag{17.5}$$

جدول رموز (16.5)–(17.5):

الرمز	المعنى	ملاحظات
S_α	سطح كرة الوحدة للناظم α (وحدة الكرة)	مجموعة مغلقة ومحدودة في بعد منتهي $\Longrightarrow$ متراصّة (Heine–Borel)
«متراصّة»	كل متتالية فيها لها متتالية جزئية تقاربية	الضمانة وراء وجود min و max
«متصلة وموجبة تماماً»	$\|x\|_\beta > 0$ لكل $x \in S_\alpha$	تمنع أن يكون الأدنى صفراً
$\operatorname{supp}(x)$	دعم المتجه: مجموعة الإحداثيات غير الصفرية	$\{i : x_i \neq 0\}$
s	عدد الإحداثيات غير الصفرية (مستوى التناثر)	$s \le n$
$s^{1/q-1/p}$	ثابت التحويل **المعتمد على التناثر**	بديلٌ لـ $n^{1/q-1/p}$
$\sqrt{s}$	الحالة الخاصة $p = 1, q = 2$	الثابت الشهير في تحليل الضغط المتناثر
$q \le p$	ترتيب الأُسّين في (17.5)	معكوس ترتيب (13.5) ظاهرياً بسبب صيغة الأُسّ

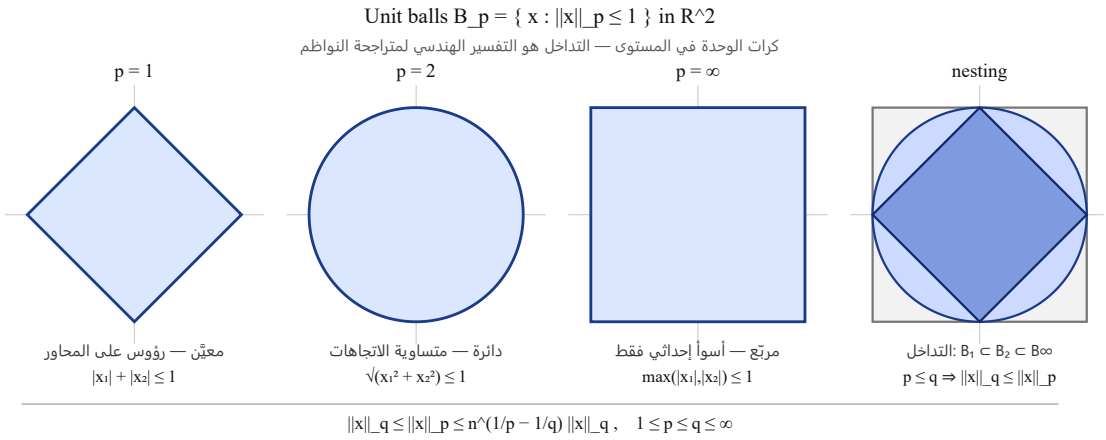
نتيجة (التحدّب وتمثيل دالة الدعم). كل ناظم دالةٌ **محدّبة**، وله تمثيل مزدوج:

$$\|\theta x + (1-\theta)y\| \;\le\; \theta\|x\| + (1-\theta)\|y\|, \quad \theta \in [0,1]; \qquad \|x\| \;=\; \max_{\|z\|_*\le 1} \langle z,\, x\rangle \tag{18.5}$$

جدول رموز (18.5):

الرمز	المعنى	ملاحظات
θ	معامل الخلط بين x و y	$\theta \in [0,1]$
$\theta x + (1-\theta)y$	النقطة على القطعة المستقيمة بينهما	—
المتراجحة اليسرى	تحدّب الناظم	يتبع من التجانس + متراجحة المثلث
$\max_{\|z\|_* \le 1}$	التعظيم على كرة الناظم **الثنوي**	—
$\langle z, x \rangle$	الشكل الخطي	—
المتطابقة اليمنى	كل ناظم = **دالة دعم** لكرته الثنوية	يربط الناظم بالهندسة المحدّبة وبالتنظيم
z	متجه الاختبار في الكرة الثنوية	عند $z = x/\|x\|_2$: $\|\cdot\|_2$

الشكل الهندسي للتكافؤ: تداخل كرات الوحدة — الكرة الأصغر أُسّاً داخل الكرة الأكبر أُسّاً، ونسبةُ التمدّد هي $n^{1/p-1/q}$:



شكل ٣.٥: *
كرات الوحدة لنواظم p وتداخلها

2.3.5 البرهان

برهان (13.5) — الحدّ الأسفل $\|x\|_q \le \|x\|_p$.

بلا فقدان العمومية نُطبّع بحيث $\|x\|_p = 1$ (التجانس يجعل ذلك مشروعاً). عندئذٍ $|x_i| \le 1$ لكل i، ومن ثم $|x_i|^q \le |x_i|^p$ لأن $q \ge p$. بالجمع:

$$\sum_i |x_i|^q \le \sum_i |x_i|^p = 1 \quad \Longrightarrow \quad \|x\|_q \le 1 = \|x\|_p$$

برهان (13.5) — الحدّ الأعلى $\|x\|_p \le n^{1/p-1/q}\|x\|_q$.

نُطبّق هولدر على المتجهين $(1,1,\dots,1)$ و $(|x_1|^p,\dots,|x_n|^p)$ بالأُسّين المترافقين $r = \frac{q}{p} \ge 1$ و $r' = \frac{q}{q-p}$:

$$\sum_i |x_i|^p \le \Big(\sum_i 1^{r'}\Big)^{1/r'} \Big(\sum_i |x_i|^{pr}\Big)^{1/r} = n^{\frac{q-p}{q}} \Big(\sum_i |x_i|^q\Big)^{\frac{p}{q}}$$

برفع الطرفين إلى الأُسّ $1/p$:

$$\|x\|_p \le n^{\frac{q-p}{pq}}\,\|x\|_q = n^{\frac{1}{p}-\frac{1}{q}}\,\|x\|_q \qquad \blacksquare$$

الإحكام: للمتجه $x=\mathbf{1}$: $\|\mathbf{1}\|_p = n^{1/p}$ و $\|\mathbf{1}\|_q = n^{1/q}$، فالنسبة $\|x\|_p/\|x\|_q = n^{1/p-1/q}$ — تبلغ الثابت تماماً. ولـ $x=e_i$: كل النواظم $=1$ فالنسبة $=1$ — تبلغ الثابت الأسفل. $\blacksquare$

برهان (14.5)-(16.5).

الدالة $\varphi(x)=\|x\|_\beta$ متصلة على V (لأن $|\varphi(x)-\varphi(y)| \le \|x-y\|_\beta \le C'\|x-y\|_\alpha$ باستخدام (13.5)) المُعمَّم أو مباشرةً من المتراجحة الفرقية). ومجموعة $S_\alpha=\{x:\|x\|_\alpha=1\}$ مغلقة ومحدودة في $V\cong\mathbb{R}^n$، فهي **متراصّة** بنظرية هاينه-بوريل. وعليه تُحقّق φ أدناها وأعلاها على S_α:

$$\exists\, x_{\min}, x_{\max} \in S_\alpha : \quad c=\varphi(x_{\min}) \le \|x\|_\beta \le \varphi(x_{\max}) = C$$

ولأن $\|x\|_\beta>0$ على S_α (إذ $x\neq 0$ هناك)، فإن $c>0$. وأخيراً، لكل $x\neq 0$ نُطبّق ذلك على $x/\|x\|_\alpha \in S_\alpha$ ونضرب بـ $\|x\|_\alpha$ فنحصل على (14.5). والعلاقة $c_{\alpha\to\beta}=1/C_{\beta\to\alpha}$ تتبع من قلب المتراجحة. $\blacksquare$

برهان (17.5).

ليكن $S=\operatorname{supp}(x)$ بـ $|S|=s$. بتطبيق (13.5) على المتجه المقيَّد x_S (وهو عنصر في $\mathbb{R}^s$) مع الأُسّين $q\le p$:

$$\|x\|_p = \|x_S\|_p \le s^{\frac{1}{q}-\frac{1}{p}}\|x_S\|_q = s^{\frac{1}{q}-\frac{1}{p}}\|x\|_q$$

وحالة $(q,p)=(2,1)$ تعطي $\|x\|_1 \le \sqrt{s}\,\|x\|_2$. بديل مباشر لها: كوشي-شفارتس على الدعم: $\sum_{i\in S}|x_i|\cdot 1 \le \sqrt{\sum_{i\in S}x_i^2}\,\sqrt{s}$. $\blacksquare$

برهان (18.5).

التحدّب: $\|\theta x+(1-\theta)y\| \le \|\theta x\|+\|(1-\theta)y\| = \theta\|x\|+(1-\theta)\|y\|$ من (N2)+(N3) مع $\theta, 1-\theta \ge 0$. وتمثيل دالة الدعم: من تعريف الثنوي $\|x\| \le \|x\|\|z\|_* \le \|x\|$ لكل $\|z\|_*\le 1$، فـ $\max \le \|x\|$؛ والعكس يتبع من (11.5)(د). $\blacksquare$

تنبيه جوهري: التكافؤ (14.5) يضمن أن **التقارب** لا يعتمد على الناظم: $x_k \to x$ بأحدها $\iff$ بأيّ آخر. لكن **سرعة** التقارب المعبَّر عنها بعدد الخطوات قد تتغيّر بثابت يعتمد على n. مثال: إن كان $\|e_k\|_2 \le \rho^k\|e_0\|_2$ فإن $\|e_k\|_1 \le \sqrt{n}\,\rho^k\|e_0\|_1$ — الرقم ρ نفسه لم يتغيّر، لكن الوصول إلى دقة مطلقة معيّنة يتطلّب $\frac{\log n}{2\log(1/\rho)}$ خطوة إضافية. هذا بالضبط هو «ثمن البعد».

3.3.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (3.5-1): تحويل بين ℓ_1 و ℓ_2 في بُعد $n = 1000$ — حدود تدرّج متوازٍ

المعطيات: تدرّج $g \in \mathbb{R}^{1000}$ ناظمه الإقليدي $\|g\|_2 = 0.35$.
المطلوب: حدود ℓ_1 الممكنة $\|g\|_1$، ومثالان يبلغان الحدّين.
الحل:

١. من (13.5) مع $(p, q) = (1, 2)$: $\|g\|_2 \le \|g\|_1 \le n^{1-1/2}\|g\|_2 = \sqrt{1000}\,\|g\|_2$.

٢. الحدّ الأسفل: $\|g\|_1 \ge 0.35$.

٣. الحدّ الأعلى: $\sqrt{1000} = 31.6228$، فـ $\|g\|_1 \le 31.6228 \times 0.35 = 11.068$.

٤. متجه يبلغ الأسفل: $g = 0.35\,e_1$ (إحداثي واحد فقط) $\Longrightarrow \|g\|_1 = \|g\|_2 = 0.35$ ✓.

٥. متجه يبلغ الأعلى: $g_i = 0.35/\sqrt{1000} = 0.011068$ لكل $i \Longrightarrow \|g\|_2 = \sqrt{1000 \times 0.011068^2} = 0.35$ و $\|g\|_1 = 1000 \times 0.011068 = 11.068$ ✓.

النتيجة: $\|g\|_1 \in [0.35,\ 11.068]$ — مجالٌ اتساعه **معامل** 31.6، ولا يمكن تضييقه بمعلومة $\|g\|_2$ وحدها.
الربط بالذكاء الاصطناعي: حين تقرأ في بحث أن «قصّ التدرّج عند ناظم 1.0» ثم تريد ترجمته إلى ميزانية ℓ_1 (كما في خوارزميات الضغط المتناثر k-top)، فهذه الفجوة بمعامل $\sqrt{n}$ هي بالضبط ما يجعل الترجمة خطرة. دوماً اذكر **أيّ** ناظم يقصد البحث؛ فالمعامل $\sqrt{1000} \approx 32$ ليس تفصيلاً.

مثال (3.5-2): اضطراب صورة $\ell_\infty = 8/255$ كم يبلغ ناظمه ℓ_2؟

المعطيات: صورة مُطبَّعة 28×28 $(n = 784)$ واضطراب خصمي بشرط $\|\delta\|_\infty \le \varepsilon = 8/255$.
المطلوب: أقصى $\|\delta\|_2$ ممكن، ومقارنته بناظم الصورة نفسها.
الحل:

١. $\varepsilon = 8/255 = 0.03137$.

٢. من (13.5) مع $(p, q) = (2, \infty)$: $\|\delta\|_\infty \le \|\delta\|_2 \le \sqrt{784}\,\|\delta\|_\infty$.

٣. الحدّ الأعلى: $\sqrt{784} = 28$، فـ $\|\delta\|_2 \le 28 \times 0.03137 = 0.8784$.

٤. الحدّ الأسفل: $\|\delta\|_2 \ge \|\delta\|_\infty = 0.03137$ (يتحقّق إذا كان الاضطراب في بكسل واحد).

٥. الإحكام: $\delta = \varepsilon\mathbf{1}$ (كل البكسلات مزاحة بالكامل) يعطي $\|\delta\|_2 = \sqrt{784 \times \varepsilon^2} = 0.8784$ ✓.

٦. المقارنة: صورة مُطبَّعة ناظمها $\|x\|_2 \approx 1$، فالاضطراب قد يبلغ 87.8% من ناظم الصورة — «غير مرئي» بالعين لكنه ضخم قياسياً.

النتيجة: $\|\delta\|_2 \in [0.03137,\ 0.8784]$ — أي حتى $0.88 \approx$ من ناظم الصورة كلها.

الربط بالذكاء الاصطناعي: هذا يحلّ اللغز الشهير: كيف يكون هجوم «غير محسوس» ($\varepsilon = 8/255$ لكل بكسل) قادراً على قلب تصنيف الشبكة؟ الجواب: لأن ميزانية ℓ_∞ الصغيرة تترجم إلى ميزانية ℓ_2 كبيرة بمعامل $\sqrt{n}$ — فالهجوم يوزّع «همسة» على كل بكسل فتجتمع 784 همسة في اتجاه واحد. أي دفاع يجب أن يقيس المتانة **بالناظم الصحيح للميزانية.**

مثال (3-3.5): التناثر يُصغّر ثابت التحويل من $\sqrt{d}$ إلى $\sqrt{s}$

المعطيات: تدرّج متناثر $g \in \mathbb{R}^{5000}$ ناظمه $\|g\|_2 = 6.4$، وعدد غير الصفري $s = 12$ (مثلاً بعد $k$top-sparsfiication).

المطلوب: قارن حدود $\|g\|_1$ بالثابت الكثيف $\sqrt{d}$ وبالثابت المتناثر $\sqrt{s}$.

الحل:

١. الحدّ الكثيف (يتجاهل التناثر): $\|g\|_1 \le \sqrt{5000} \times 6.4 = 70.711 \times 6.4 = 452.5$.

٢. الحدّ المتناثر (17.5): $\|g\|_1 \le \sqrt{12} \times 6.4 = 3.4641 \times 6.4 = 22.17$.

٣. نسبة التحسين: $\sqrt{5000/12} = \sqrt{416.7} = 20.41 = 452.5/22.17$ ✓.

٤. الحدّ الأسفل في الحالتين: $\|g\|_1 \ge \|g\|_2 = 6.4$ (يتحقّق إذا تركّز الناظم في إحداثي واحد).

٥. الإحكام: لو كانت الـ 12 قيم غير الصفرية متساوية المقدار $|g_i| = 6.4/\sqrt{12} = 1.8475$، لكان $\|g\|_1 = 12 \times 1.8475 = 22.17$ ✓.

النتيجة: $\|g\|_1 \in [6.4,\ 22.17]$ بدلاً من $[6.4,\ 452.5]$ — تحسين بمعامل 20.4.

الربط بالذكاء الاصطناعي: هذا هو المبرّر الرياضي الكامل لـ **ضغط التدرّجات المتناثر** في التدريب الموزّع ($k$top-Compression): Gradient Deep sparsfiication، الخطأ المُدخَل يُقاس بـ $\|g - g_s\|$، وحدوده تتقلّص مع $\sqrt{s}$ لا مع $\sqrt{d}$. كلما زاد التناثر تحسّنت الحدود، وإن ظلّ الناظم الإقليدي ثابتاً.

مثال (4-3.5): ثمن البعد — كم خطوة إضافية يكلّفها قياس الخطأ بـ ℓ_∞ بدل ℓ_2؟

المعطيات: خوارزمية تكرارية تتقارب خطياً: $\|e_k\|_2 \le \rho^k \|e_0\|_2$ بـ $\rho = 0.9$ و $n = 300$. المطلوب أن يصل الخطأ إلى $\tau = 10^{-3}$، والخطأ الابتدائي $\|e_0\|_\infty = 1$.

المطلوب: عدد التكرارات إن قِسنا الخطأ بـ ℓ_2، وإن قِسناه بـ ℓ_∞.

الحل:

١. التحويل الابتدائي: $\|e_0\|_2 \le \sqrt{n}\,\|e_0\|_\infty = \sqrt{300} = 17.3205$.

٢. قياس ℓ_2: نحتاج $\rho^k \le 0.001$، أي $k \ge \dfrac{\ln(10^{-3})}{\ln(0.9)} = \dfrac{-6.9078}{-0.10536} = 65.56 \Rightarrow k = 66$.

٣. قياس ℓ_∞: $\|e_k\|_\infty \le \|e_k\|_2 \le \rho^k \|e_0\|_2 \le \rho^k \sqrt{300}$. نحتاج $0.9^k \times 17.3205 \le 10^{-3}$، أي $0.9^k \le 5.7735 \times 10^{-5}$، فـ $k \ge \dfrac{\ln(5.7735 \times 10^{-5})}{\ln(0.9)} = \dfrac{-9.7582}{-0.10536} = 92.62 \Rightarrow k = 93$.

٤. الفرق: $93 - 66 = 27$ تكراراً إضافياً.

٥. الصيغة العامة للفرق: $\dfrac{\ln \sqrt{n}}{\ln(1/\rho)} = \dfrac{2.8519}{0.10536} = 27.07$ ✓.

النتيجة: معدّل التقارب $\rho = 0.9$ **لم يتغيّر**، الذي تغيّر هو الثابت، فأضاف 27 تكراراً (41% ≈ زيادة).
الربط بالذكاء الاصطناعي: هذه هي الدلالة الدقيقة لقولنا «التكافؤ لا يعني التساوي». في تقارير التدريب، الانتقال من معيار توقّف على $\|g\|_2$ إلى معيار على $\|g\|_\infty$ (أو على تغيّر الخسارة) يغيّر عدد الخطوات الملحوظة دون أن يغيّر الخوارزمية. وعند مقارنة طريقتين في بحث، يجب أن يُقاس الخطأ **بالناظم نفسه** وإلا كانت المقارنة مضلّلة بمعامل $\sqrt{n}$.

مثال (5-3.5): تحويل ثابت ليبشيتز من ℓ_2 إلى ℓ_∞ — والتحسين المتناثر

المعطيات: طبقة جاكوبيها J بشرط $\|J\|_2 \le L_2 = 2.5$، والمدخل صورة $n = 784$ بُعداً.
المطلوب: ثابت ليبشيتز بالناظمين: من $(\mathbb{R}^n, \ell_\infty)$ إلى $(\mathbb{R}, \ell_\infty)$ للحالة العامة، ولحالة اضطراب متناثر على $s = 20$ بكسلاً.
الحل:

١. تعريف ثابت ليبشيتز بالناظمين α (مدخل) و β (خرج): $\|J\delta\|_\beta \le L_{\alpha\to\beta} \|\delta\|_\alpha$.

٢. الحالة العامة $(\ell_\infty \to \ell_\infty)$: $\|J\delta\|_\infty \le \|J\delta\|_2 \le \|J\|_2 \|\delta\|_2 \le L_2 \sqrt{n}\, \|\delta\|_\infty$. إذن $L_{\infty\to\infty} \le 2.5 \times 28 = 70$.

٣. الحالة المتناثرة: من (17.5)، $\|J\delta\|_\infty \le \|\delta\|_2 \le \sqrt{s}\, \|\delta\|_\infty = \sqrt{20}\, \|\delta\|_\infty = 4.4721 \|\delta\|_\infty$. إذن $2.5 \times 4.4721 = 11.18$.

٤. نسبة التحسين: $70/11.18 = 6.26 = \sqrt{784/20} = \sqrt{39.2} = 6.26$ ✓.

النتيجة: $L_{\infty\to\infty} = 70$ للاضطراب العام، و 11.18 لاضطراب على 20 بكسلاً فقط — تحسين بمعامل 6.26.
الربط بالذكاء الاصطناعي: هذا هو جوهر **التحقّق الرسمي من المتانة** (certfiied robustness): كلّما استطعت تقييد «دعم» الاضطراب (عدد البكسلات أو الكلمات المعدَّلة)، تحسّن الحدّ المضمون بمعامل $\sqrt{s/n}$ بلا أي تغيير في النموذج. لهذا تُعدّ الهجمات «الموضعية» (لصقة صغيرة، تعديل كلمات قليلة) أصعب إثباتاً للأمان من الهجمات الشاملة، ولهذا تُقاس المتانة دائماً **مقرونة بميزانية وموضع**.

مثال (6-3.5): بين الناظم الطيفي والناظم الفروبنيوسي لمصفوفة أوزان 768×1024

المعطيات: مصفوفة أوزان $W \in \mathbb{R}^{1024\times 768}$، ناظمها الطيفي $\|W\|_2 = \sigma_1 = 3.2$.
المطلوب: حدود $\|W\|_F$ الممكنة، والحالتان اللتان تبلغان الحدّين.
الحل:

١. العلاقة: $\|W\|_F^2 = \sum_{i=1}^{r} \sigma_i^2 \le r\,\sigma_1^2$ حيث $r = \text{rank}(W) \le \min(1024, 768) = 768$.

٢. الحدّ الأعلى: $\|W\|_F \le \sqrt{768} \times 3.2 = 27.7128 \times 3.2 = 88.68$.

٣. الحدّ الأسفل: $\|W\|_F \ge \sigma_1 = 3.2$.

٤. الحالة المُحقِّقة للأسفل: $\text{rank}(W) = 1$ (كل القيم المفردة الأخرى صفر) $\Longrightarrow \|W\|_F = 3.2$ ✓.

٥. الحالة المُحقِّقة للأعلى: كل القيم المفردة الـ 768 متساوية $3.2 \Longrightarrow \|W\|_F = \sqrt{768 \times 10.24} = 88.68$ ✓.

النتيجة: $3.2 \le \|W\|_F \le 88.68$.
الربط بالذكاء الاصطناعي: كثير من بحوث تنظيم الأوزان تستخدم $\|W\|_F$ (تنظيم «weight decay») لكن التحليل النظري يستخدم $\|W\|_2$ (لأنه ثابت ليبشيتز). التحويل بينهما يكلّف معاملاً حتى ≈ 27.7 $\sqrt{\min(m,n)}$. ولهذا ظهرت تقنيات **التطبيع الطيفي** (spectral normalization) التي تقترب من $\|W\|_2$ مباشرة: فهي تضبط الكمية التي تتحكّم فعلاً باستقرار الشبكة، لا بديلاً عنها بفجوة $\sqrt{\text{width}}$.

مثال (5.3-7): لماذا يجب إعادة ضبط معامل التنظيم عند تغيير عرض الشبكة؟

المعطيات: نموذجان خطيان متشابهان: A بـ $n_A = 1000$ معلمة وناظم $\|w_A\|_1 = 5$؛ و B بـ $n_B = 4000$ معلمة وناظم $\|w_B\|_1 = 5$.
المطلوب: قارن $\|w\|_2$ المُضمَّن في كل نموذج، واستنتج كيف يجب أن يتغيّر معامل تنظيم ℓ_2 عند مضاعفة العرض.
الحل:

١. من (5.13): $\frac{\|w\|_1}{\sqrt{n}} \le \|w\|_2 \le \|w\|_1$.

٢. النموذج A: $\|w_A\|_2 \in [5/\sqrt{1000},\ 5] = [0.1581,\ 5]$.

٣. النموذج B: $\|w_B\|_2 \in [5/\sqrt{4000},\ 5] = [0.0791,\ 5]$.

٤. بافتراض الحالة «النموذجية» (المعاملات متقاربة المقدار، فتكون القيمة قرب الحدّ الأسفل): $\|w_A\|_2 \approx 0.1581$ و $\|w_B\|_2 \approx 0.0791$؛ والنسبة $0.1581/0.0791 = 2 = \sqrt{4000/1000}$ ✓.

٥. أثر ذلك على الجزاء: $\lambda\|w\|_2^2$ يصبح $\lambda \times 0.025$ لـ A مقابل $\lambda \times 0.00626$ لـ B — أي أن الجزاء الفعلي على B أضعف بـ 4 أضعاف $= n_B/n_A$.

٦. التصحيح: للحفاظ على القوّة نفسها يجب أن يُضبط λ مع n: $\lambda \propto n$ (أو ما يكافئه: تقسيم الجزاء على البعد، كما في تطبيع «fan-in»).

النتيجة: مضاعفة العرض $\times 4$ مع إبقاء $\|w\|_1$ و λ ثابتين يُضعف الجزاء الفعلي ℓ_2 بمعامل 4.

الربط بالذكاء الاصطناعي: هذا يفسّر ظاهرة عملية معروفة: نقل معامل decay weight بين نماذج مختلفة العرض (أو بين نموذج ومكمّله المضغوط) يغيّر سلوك التدريب. الحدود النظرية (13.5) تعطي المعامل الصحيح للتصحيح: λ يجب أن يتناسب مع البعد عند تثبيت الناظم ℓ_1، ومع $\sqrt{\text{width}}$ في حالات أخرى. القاعدة العملية: **عيّن التنظيم بوصفه «ناظماً مستهدفاً» لا «رقماً سحرياً».**

مثال (3.5-8): اختيار مقياس المسافة في فهرس البحث المتجهي (ANN)

المعطيات: تضمينات بُعد $d = 768$ في قاعدة بيانات متجهية. نعلم أن $\|x - y\|_2 = 0.6$ لزوج معيّن.

المطلوب: حدود ℓ_1 الموافقة؛ ثم عكس المسألة: إن كان عتبة الاسترجاع بالـ ℓ_1 هي 12، فما المرافق لها بـ ℓ_2؟

الحل:

١. الاتجاه الأول: $\|x-y\|_1 \le \sqrt{768}\,\|x-y\|_2 = 27.7128 \times 0.6 = 16.63$. ف $\|x-y\|_2 \le \|x-y\|_1$. $\|x-y\|_1 \in [0.6,\ 16.63]$.

٢. الاتجاه الثاني: $\frac{\|x-y\|_1}{\sqrt{768}} \le \|x-y\|_2 \le \|x-y\|_1$، أي $\|x-y\|_2 \in \left[\frac{12}{27.7128},\ 12\right] = [0.4330,\ 12]$.

٣. الفجوة في الحالتين بمعامل $\sqrt{768} = 27.7$ — لا يمكن تجاوزها بلا معلومة إضافية عن توزيع الفروق.

النتيجة: عتبة $\ell_1 = 12$ تقابل مجالاً كاملاً $[0.433,\ 12]$ من مسافات ℓ_2 — فالعتبتان **غير قابلتين للترجمة** بعامل ثابت.

الربط بالذكاء الاصطناعي: محرّكات البحث المتجهي (FAISS، HNSW، ScaNN) تبني فهارسها على مقياس واحد. الانتقال من ℓ_2 (أو الجداء الداخلي) إلى ℓ_1 يبدو تغييراً بسيطاً، لكن حدود التحويل بمعامل $\sqrt{d} = 27.7$ تعني أن **كل عتبة وكل معلمة فهرس يجب إعادة ضبطها.** ولهذا يشيع استخدام المسافة الإقليدية أو الجداء الداخلي: فهما ثابتان دورانياً، في حين أن ℓ_1 يعتمد على محاور الإحداثيات — وهو ما يجعله حسّاساً لتدوير الفضاء (مثل بعد PCA أو بعد طبقة تكييف).

مثال (3.5-9): ثوابت التكافؤ بين مسافة مالانوبيس والمسافة الإقليدية

المعطيات: مصفوفة تغاير $\Sigma = \text{diag}(4,\ 1,\ 0.25)$ لثلاث ميزات، ومسافة مالانوبيس $d_\Sigma(x,y) = \sqrt{(x-y)^\top \Sigma^{-1}(x-y)}$.

المطلوب: ثابتا التكافؤ مع المسافة الإقليدية، وتحقّق رقمي على متجه، وأثر ذلك على عتبة كشف الشذوذ.

الحل:

١. $\Sigma^{-1} = \text{diag}(0.25,\ 1,\ 4)$. قيمها الذاتية $(0.25,\ 1,\ 4)$.

٢. من (6.5) مع $G = \Sigma^{-1}$: $\sqrt{\lambda_{\min}(G)}\,\|z\|_2 \le \|z\|_G \le \sqrt{\lambda_{\max}(G)}\,\|z\|_2$، أي $0.5\|z\|_2 \le \|z\|_G \le 2\|z\|_2$.

٣. نسبة التمدّد: $C/c = 2/0.5 = 4 = \sqrt{\kappa(\Sigma)}$ حيث $\kappa(\Sigma) = 4/0.25 = 16$ ✓.

٤. تحقّق رقمي على $z = (0.5,\ 1.2,\ -0.3)^\top$: $\|z\|_2 = \sqrt{0.25 + 1.44 + 0.09} = \sqrt{1.78} = 1.3342$؛ و $z^\top \Sigma^{-1} z = 0.25 \times 0.25 + 1 \times 1.44 + 4 \times 0.09 = 0.0625 + 1.44 + 0.36 = 1.8625$؛ فـ $\|z\|_G = \sqrt{1.8625} = 1.3647$.

٥. التحقّق: $0.5 \times 1.3342 = 0.6671 \le 1.3647 \le 2 \times 1.3342 = 2.6684$ ✓.

النتيجة: المسافتان متكافئتان بثابتين $(0.5,\ 2)$؛ فأي عتبة إقليدية تُترجم إلى عتبة مالانوبيس بعامل غير محدّد في المدى $[0.5,\ 2]$.

الربط بالذكاء الاصطناعي: مسافة مالانوبيس هي المعيار في كشف الشذوذ متعدّد المتغيّرات وفي تعلّم المسافة. حدود التكافؤ تخبرنا بأمرين: (أ) **الترتيب** بين النقاط قد يتغيّر فعلاً عند الانتقال بين المسافتين (الفجوة بمعامل 4 هنا)، فلا يجوز افتراض تطابق النتائج؛ (ب) متى كانت $\kappa(\Sigma)$ كبيرة — أي ميزات مترابطة بقوة أو ذات تباينات متباينة جداً — اتّسعت الفجوة، وهذا بالضبط ما يجعل تبييض البيانات (whitening) خطوةً مسبقة ضرورية قبل NNk أو التجميع.

مثال (10-3.5): ميزانية القصّ ℓ_2 مقابل ℓ_∞ في نموذج بـ 10^6 معلمة

المعطيات: نموذج بـ $d = 10^6$ معلمة. خياران للقصّ: (أ) $\|g\|_2 \le 1.0$؛ (ب) $\|g\|_\infty \le 0.01$.

المطلوب: كم يبلغ الآخر في كل خيار؟ وأيّ الخيارين أشدّ؟

الحل:

١. من (أ) إلى (ب): $\|g\|_\infty \le \|g\|_2 \le 1.0$. فكل إحداثي مضمونٌ $|g_i| \le 1.0$ — وهو حدّ فضفاض جداً. ولو كان التحديث موزّعاً بالتساوي: $|g_i| = 1.0/\sqrt{10^6} = 10^{-3}$.

٢. من (ب) إلى (أ): $\|g\|_2 \le \sqrt{d}\,\|g\|_\infty = 1000 \times 0.01 = 10.0$. فالميزانية الإقليدية قد تصل إلى 10.0.

٣. المقارنة: الخيار (ب) يسمح بتحديث إقليدي أكبر بـ 10 أضعاف من الخيار (أ) (في أسوأ توزيع)، والفجوة بينهما معامل $\sqrt{d} = 1000$ في الاتجاه المعاكس.

٤. الخياران **غير قابلين للترجمة**، ولا يوجد أحدهما «أقوى» بإطلاق: (أ) يقيد الطول الكلي، (ب) يقيد أقصى إحداثي.

النتيجة: قصّ ℓ_2 عند 1.0 يقابله قصّ ℓ_∞ عند أي قيمة في $[10^{-3},\ 1.0]$ بحسب توزيع التحديث.

الربط بالذكاء الاصطناعي: هذا مثال حاسم على أن «مقدار القصّ» ليس رقماً كونياً. في النماذج الضخمة $(d \sim 10^9)$، الفجوة $\sqrt{d}$ تبلغ $31623 \approx$ — فذكر «قمنا بقصّ التدرّجات عند 1.0» بلا تحديد الناظم لا يعني شيئاً قابلاً للتكرار. كذلك «التنعيم التفاضلي الخصوصي» (DP-SGD) يعمل صراحةً بميزانية ℓ_2 لأن تحليل الخصوصية مبنيّ على حساسية ℓ_2 — وتحويلها إلى ℓ_∞ يفقد المعامل $\sqrt{d}$ كاملاً.

مثال (11-3.5): إحكام حدود التحويل — ثلاثة متجهات تبلغ ثلاثة حدود

المعطيات: $n = 64$. ثلاثة متجهات: $a = \mathbf{1}$ (كل إحداثياته 1)، و $b = e_1$، و c متناثر بـ $s = 4$ إحداثيات قيمتها 1 والباقي صفر.

المطلوب: تحقّق أن كل متجه يبلغ حدّاً مختلفاً من حدود (13.5) و (17.5).

الحل:

١. $a = \mathbf{1}$: $\|a\|_1 = 64$، $\|a\|_2 = \sqrt{64} = 8$، $\|a\|_\infty = 1$.

- $\|a\|_1/\|a\|_2 = 64/8 = 8 = \sqrt{64} \implies$ **يبلغ الحدّ الأعلى** لـ $(p,q) = (1,2)$ ✓
- $\|a\|_2/\|a\|_\infty = 8/1 = 8 = \sqrt{64} \implies$ **يبلغ الحدّ الأعلى** لـ $(p,q) = (2,\infty)$ ✓

١. $b = e_1$: $\|b\|_1 = \|b\|_2 = \|b\|_\infty = 1$. كل النسب $= 1 \implies$ **يبلغ الحدّ الأسفل** في الحالتين ✓.

٢. c $(s = 4)$: $\|c\|_1 = 4$، $\|c\|_2 = 2$، $\|c\|_\infty = 1$.

- $\|c\|_1/\|c\|_2 = 2 = \sqrt{4} = \sqrt{s} \implies$ **يبلغ حدّ (17.5) المتناثر** ✓، في حين أن الحدّ الكثيف $\sqrt{64} = 8$ فضفاض بمعامل 4.

النتيجة: الحدود في (13.5) و (17.5) **محكمة** — لا يمكن تحسين أيٍّ منها، وبيان ذلك هذه المتجهات الثلاثة.

الربط بالذكاء الاصطناعي: اختبار الإحكام ليس ترفاً نظرياً: حين تُثبَت أن حدّاً ما محكَم، تعرف أن تحسينه يحتاج **معلومة إضافية** (تناثر، بنية كتلية، انخفاض رتبة) لا تحسيناً في التحليل. وهذا بالضبط ما يوجّه البحث: كل تحسين في حدود التعميم جاء من إدخال معلومة بنيوية جديدة لا من شحذ المتراجحة.

مثال (12-3.5): تقرير خطأ المُحلّل التكراري بأيّ ناظم؟

المعطيات: متجه خطأ $e = (0.012,\ -0.008,\ 0.010,\ -0.010)^\top$ على $\mathbb{R}^4$.

المطلوب: النواظم الثلاثة للخطأ، وأثر اختيار الناظم على «الرقم المُعلَن».

الحل:

١. $\|e\|_1 = 0.012 + 0.008 + 0.010 + 0.010 = 0.040$.

٢. $\|e\|_2 = \sqrt{0.000144 + 0.000064 + 0.0001 + 0.0001} = \sqrt{0.000408} = 0.020199$.

٣. $\|e\|_\infty = 0.012$.

٤. التحقّق من (13.5): $0.040 \le 0.020199 \le 0.012$ ✓، والحدّ الأعلى $\sqrt{4} \times 0.012 = 0.024 \ge 0.020199$ ✓.

٥. الإحكام هنا: $\|e\|_1 = 0.040$ قريب من الحدّ الأعلى $2 \times 0.020199 = 0.040398$ لأن الإحداثيات متقاربة المقدار.

٦. الأثر على التقرير: الرقم نفسه يتراوح من 0.012 إلى 0.040 بحسب الناظم — أي بمعامل 3.33.

النتيجة: «الخطأ 0.012 =» (بـ ℓ_∞) و «الخطأ 0.040 =» (بـ ℓ_1) يصفان **الحل نفسه**، والفرق معامل 3.33.

الربط بالذكاء الاصطناعي: عند قراءة جداول دقّة المُحلّلات العددية أو تقارير تقارب التدريب، الناظم جزءٌ من القياس لا تفصيلٌ هامشي. الممارسة السليمة: الإعلان عن الناظم صراحةً، ويفضّل الإعلان عن $\|e\|_2/\|e_0\|_2$ (نسبة لا dimension-dependent بقدر أقل) مع ذكر معيار التوقّف. سنعود إلى هذا في الفصل السادس (التحليل العددي والاستقرار).

مثال (3.5-13): خطأ التكميم — الحدّ الأسوأ مقابل السلوك النموذجي

المعطيات: مصفوفة أوزان $W \in \mathbb{R}^{512\times 512}$ مُكمَّمة بخطوة $\Delta = 2^{-7} = 0.0078125$ (تكميم منتظم)، فخطأ كل إحداثي $\le \Delta/2$.

المطلوب: حدّ أسوأ حالة على $\|\Delta W\|_2$ باستخدام التكافؤ، ومقارنته بالقيمة النموذجية لخطأ التقريب.

الحل:

١. خطأ الإحداثي: $|\Delta W_{ij}| \le \Delta/2 = 0.00390625$.

٢. الحدّ بـ ℓ_∞: $\|\Delta W\|_\infty$ (كناظم أقصى إحداثي) ≤ 0.00390625.

٣. التحويل إلى الطيفي عبر الفروبنيوسي: $\|\Delta W\|_2 \le \|\Delta W\|_F = \sqrt{\sum_{ij}\Delta W_{ij}^2} \le \sqrt{mn}\,(\Delta/2) = 512 \times 0.00390625 = 2.0$.

٤. القيمة النموذجية (خطأ تقريب شبيه بالعشوائي، توزيع منتظم على $[-\Delta/2, \Delta/2]$): الانحراف المعياري للإحداثي $\sigma = \dfrac{\Delta}{2\sqrt{3}} = \dfrac{0.0078125}{3.4641} = 0.0022555$؛ وبتركيز ناظم المصفوفة العشوائية (§6.5): $\|\Delta W\|_2 \approx \sigma(\sqrt{m}+\sqrt{n}) = 0.0022555 \times (22.627 + 22.627) = 0.1021$.

٥. المقارنة: أسوأ حالة 2.0 مقابل نموذجي 0.1021 — فجوة بمعامل ≈ 19.6.

النتيجة: حدّ التكافؤ الأسوأ (2.0) صحيح لكنه متشائم جداً، والقيمة المرجوّة ≈ 0.10.

الربط بالذكاء الاصطناعي: هذه الفجوة بمعامل ≈ 20 هي السبب المباشر لوجود قسم كامل عن **تركيز النواظم** (§6.5): حدود أسوأ حالة مبنية على التكافؤ Deterministic تكون فارغة من المعنى في الأبعاد العالية، لأنها تفترض أن كل الإحداثيات تتآمر في الاتجاه الأسوأ. التكميم بعد التدريب (PTQ) يعتمد في الواقع على أن خطأ التقريب **شبيه بالعشوائي**، فتُستخدم حدود احتمالية لا حدود أسوأ حالة. وسنرى أن الفجوة تتّسع مع $\sqrt{mn}$ مقابل $\sqrt{m}+\sqrt{n}$.

مثال (3.5-14): لماذا يُنتج ℓ_1 حلولاً متناثرة؟ — المقارنة الهندسية الكاملة

المعطيات: قيد خطي $\langle w, a\rangle = 1$ مع $a = (1,1)^\top$. المطلوب تصغير ثلاثة نواظم مختلفة لـ $w = (t,\, 1-t)^\top$.

المطلوب: الحل الأمثل وقيمة الناظم في كل حالة، والاستنتاج الهندسي.

الحل:

١. كل الحلول الممكنة هي $w(t) = (t,\ 1-t)$ مع $t \in \mathbb{R}$.

٢. **تصغير** $\|w\|_1$: $|t| + |1-t|$. على المدى $t \in [0,1]$ القيمة $= t + 1 - t = 1$؛ وخارجه > 1. إذن القيمة الدنيا 1 **تُحقَّق على قطعة كاملة** $t \in [0,1]$، ومنها الركنان $(1,0)$ و $(0,1)$ — **حلول متناثرة**.

٣. **تصغير** $\|w\|_2$: $\sqrt{t^2 + (1-t)^2}$؛ المشتقّة تعطي $2t - 2(1-t) = 0 \Rightarrow t = \frac{1}{2}$. القيمة $= \sqrt{0.25 + 0.25} = 0.7071$ — **حل وحيد** غير متناثر.

٤. **تصغير** $\|w\|_\infty$: $\max(|t|, |1-t|)$؛ يُصغَّر عند $t = \frac{1}{2}$ بالقيمة 0.5 — **حل وحيد**.

٥. الترتيب: $1 \le 0.7071 \le 0.5$ ✓ مطابق لـ $\|w\|_\infty \le \|w\|_2 \le \|w\|_1$.

النتيجة: ℓ_1 يعطي **أكبر** قيمة دنيا للناظم (1 مقابل 0.7071 و 0.5) — ومع ذلك هو الذي يُنتج التناثر، لأنه يعطي **مجموعة حلول** تتضمّن أركاناً على المحاور، في حين أن ℓ_2 و ℓ_∞ يعطيان حلولاً وحيدة داخلية.

الربط بالذكاء الاصطناعي: التناثر ليس «لأن ℓ_1 أصغر»، بل لأن **كرة** ℓ_1 **لها أركان حادّة على محاور الإحداثيات**: حين تتمدّد كرة الوحدة حتّى تلامس مستوى القيد، فأرجح نقطة تلامس هي ركنٌ يقع على محور — أي أن بعض الإحداثيات تصفر تماماً. كرة ℓ_2 ملساء فنقطة التماس عامّة الموضع. هذا هو التفسير الهندسي الكامل لـ Lasso وتقليم الأوزان وضغط النماذج المتناثر (sparse pruning)، وهو ما لا تستطيع حدود التكافؤ وحدها تفسيره: فالتكافؤ يتحدّث عن **المقادير**، والتناثر يتحدّث عن **الشكل**.

مثال (3.5-15): لا ناظم «أفضل دائماً» — الحدود تقيس جداءً لا ناظماً مفرداً

المعطيات: حدّ تعميم من نمط راديماخر لمصنّف خطي: excess $\lesssim \dfrac{2\Lambda}{\sqrt{N}}$ حيث $\Lambda = \|w\| \cdot \max_x \|x\|_*$ (الناظم مقروناً بثنويه). لدينا: $\|w\|_1 = 200$، $\|w\|_2 = 8$؛ وميزات صور 28×28 مُخزَّنة بمدى بكسل $[0,1]$ في الحالة (أ)، ومُطبَّعة بوحدة الناظم في الحالة (ب). عدد العيّنات $N = 10^4$.

المطلوب: أيّ اختيار للناظم يعطي حدّاً أحكم في كل حالة؟

الحل:

١. الحالة (أ) — الميزات الخام: $\max \|x\|_\infty = 1$ و $\max \|x\|_2 = \sqrt{784} = 28$.

- اقتران ℓ_1/ℓ_∞: $\Lambda_1 = \|w\|_1 \max \|x\|_\infty = 200 \times 1 = 200$.
- اقتران ℓ_2/ℓ_2: $\Lambda_2 = \|w\|_2 \max \|x\|_2 = 8 \times 28 = 224$.
- إذن $200 < 224$: **الاقتران** ℓ_1 **أحكم هنا**، رغم أن $\|w\|_1 = 200 \gg \|w\|_2 = 8$.
- الحدّان: $2 \times 200/100 = 4.00$ مقابل $2 \times 224/100 = 4.48$.

١. الحالة (ب) — بعد تطبيع الميزات إلى $\max \|x\|_2 = 1$ و $\max \|x\|_\infty \le 1$ (نأخذ 1 كأسوأ حالة).

- $\Lambda_1 = 200 \times 1 = 200$؛ $\Lambda_2 = 8 \times 1 = 8$.

- إذن $200 \gg 8$: **الاقتران** ℓ_2 **أحكم بـ** 25 **مرة.**

١. الاستنتاج: تطبيع الميزات غيّر أيّ ناظم أفضل — والفرق معامل 25.

النتيجة: الأفضلية ليست للناظم بل **للجداء** $\|x\|_* \cdot \max \|w\|$؛ وتطبيع الميزات يغيّر النتيجة جذرياً.
الربط بالذكاء الاصطناعي: هذه هي الرسالة المنهجية الأهم في هذا الفصل: حين تقرأ «حدّ تعميم يتناسب مع $\|w\|$»، اسأل فوراً: **ناظم** w **مقابل ناظم ثنوي لأيّ مجموعة ميزات؟** التحسين الحقيقي يأتي عادةً من جعل $\|x\|_*$ صغيراً (تطبيع، تبييض، تقليم الميزات) لا من تصغير $\|w\|$ وحده. وكل حدود التعميم في الجزء السادس مبنية على هذا الجداء بالضبط.

4.3.5 أخطاء شائعة في استخدام تكافؤ النواظم

الخطأ الشائع	لماذا هو خطأ؟	التصحيح
افتراض $\|x\|_2 \approx \|x\|_1$ في الأبعاد العالية	الفجوة تصل إلى $\sqrt{n}$: عند $n = 10^6$ معامل 1000	استخدم (13.5) صريحاً، ولا تترجم بين النواظم إلا بذكر المعامل
استخدام التكافؤ في فضاءات **الدوال** (أبعاد لانهائية)	التكافؤ يفشل: $\|f\|_\infty$ و $\|f\|_2$ غير متكافئين	تحقّق من منتهي البعد قبل تطبيق (14.5)
ظنّ أن الثوابت في (14.5) مستقلّة عن البعد	هي تعتمد على n صراحةً في عائلة ℓ_p	احتفظ بـ n (أو s إن وُجد تناثر) داخل الحدّ
تطبيق الحدّ الكثيف $\sqrt{d}$ على متجه متناثر	حدّ فضفاض بمعامل $\sqrt{d/s}$	استخدم (17.5): الثابت $\sqrt{s}$
اد أن «التقارب لا يعتمد على الناظم» يعني «نفس عدد الخطوات»	المعدّل نفسه، لكن الثابت يضيف خطوة $\frac{\ln \sqrt{n}}{\ln(1/\rho)}$	قِس الخطأ بناظم واحد عند مقارنة خوارزميتين
ترجمة عتبة استرجاع من ℓ_1 إلى ℓ_2 بعامل ثابت	العتبة تقابل مجالاً كاملاً باتساع $\sqrt{d}$	أعد ضبط العتبة على البيانات، ولا تترجمها
استخدام $\|W\|_F$ بديلاً عن $\|W\|_2$ بلا معامل	الفجوة حتى $\sqrt{\min(m,n)}$	اذكر الناظم المقصود؛ واستخدم التطبيع الطيفي إن كان المطلوب $\|W\|_2$
نقل λ (وزن التنظيم) بين نماذج مختلفة العرض	الجزاء الفعلي يتغيّر بعامل البعد	اضبط λ مع البعد، أو عبّر عن التنظيم بناظم مستهدف
تفسير تناثر Lasso بأنه «لأن ℓ_1 أصغر من ℓ_2»	السبب **هندسي**: أركان كرة ℓ_1 على المحاور	انظر إلى شكل كرة الوحدة، لا إلى قيمة الناظم
الاعتماد على الحدّ الأسوأ لتحليل أخطاء عشوائية (تكميم، تقريب)	الحدّ متشائم بمعامل يقارب $\sqrt{mn}/(\sqrt{m}+\sqrt{n})$	استخدم حدود التركيز الاحتمالية (6.5§)

الفكرة في سطر: المصفوفةُ **مشغّل** :(operator) تأخذ متجهاً وتُخرج متجهاً. فناظمها «الصحيح» ليس طولَها بوصفها قائمة أرقام، بل **أقصى تمديد** تُحدثه: $\max_{\|x\|=1} \|Ax\|$. هذه القراءة وحدها تُعطي الخاصية التي تجعل كل تحليل استقرار ممكناً — **التضاعف التحتي** $\|AB\| \leq \|A\|\,\|B\|$ — أي أن تمديدَ التركيب لا يتجاوز جداء التمديدات.

1.4.5 الصياغة الرسمية

تعريف (الناظم المستحث / ناظم المشغّل).

ليكن $A \in \mathbb{R}^{m\times n}$، وليكن $\|\cdot\|_\alpha$ ناظماً على $\mathbb{R}^n$ و $\|\cdot\|_\beta$ ناظماً على $\mathbb{R}^m$. الناظم المستحث من α إلى β هو:

$$\|A\|_{\alpha\to\beta} = \max_{\|x\|_\alpha=1} \|Ax\|_\beta = \max_{x\neq 0} \frac{\|Ax\|_\beta}{\|x\|_\alpha} = \sup_{x\neq 0} \frac{\|Ax\|_\beta}{\|x\|_\alpha} \tag{19.5}$$

جدول رموز (19.5):

الرمز	المعنى	ملاحظات
A	مصفوفة $m \times n$ = تحويل خطي $\mathbb{R}^n \to \mathbb{R}^m$	المشغّل
α	ناظم فضاء **المدخل** $\mathbb{R}^n$	—
β	ناظم فضاء **الخرج** $\mathbb{R}^m$	قد يختلف عن α
$\|A\|_{\alpha\to\beta}$	الناظم المستحث من α إلى β	يُقرأ: «ناظم المشغّل من α إلى β»
$\max_{\|x\|_\alpha=1}$	التعظيم على سطح كرة الوحدة للمدخل	يكافئ التعظيم على كل $x \neq 0$ بفضل التجانس
$\|Ax\|_\beta$	ناظم الخرج	البسط
$\|x\|_\alpha$	ناظم المدخل	المقام
$x \neq 0$	استبعاد المتجه الصفري	القسمة على صفر غير معرّفة
sup	الحدّ الأعلى	هنا يتحقّق كـ max لتراصّ كرة الوحدة

نظرية (النواظم الأربعة الكبرى وصيغها المغلقة).

لكل $A \in \mathbb{R}^{m\times n}$:

$$\begin{aligned} \|A\|_2 &= \|A\|_{2\to 2} = \sigma_1(A) = \sqrt{\lambda_{\max}(A^\top A)} = \sqrt{\lambda_{\max}(AA^\top)} \\ \|A\|_1 &= \|A\|_{1\to 1} = \max_{1\le j\le n} \sum_{i=1}^{m} |a_{ij}| \quad \text{(أكبر مجموع عمود)} \\ \|A\|_\infty &= \|A\|_{\infty\to\infty} = \max_{1\le i\le m} \sum_{j=1}^{n} |a_{ij}| \quad \text{(أكبر مجموع صف)} \\ \|A\|_F &= \|A\|_{S_2} = \sqrt{\operatorname{tr}(A^\top A)} = \sqrt{\textstyle\sum_{i,j} a_{ij}^2} = \sqrt{\textstyle\sum_i \sigma_i^2} \end{aligned} \tag{20.5}$$

جدول رموز (20.5):

الرمز	المعنى	ملاحظات
$\|A\|_2$	الناظم الطيفي = ناظم المشغّل الإقليدي	أكبر تمديد؛ = أكبر قيمة مفردة
$\sigma_1(A)$	أكبر قيمة مفردة (singular value) لـ A	$\sigma_1 \ge \sigma_2 \ge \cdots \ge 0$
$\lambda_{\max}(\cdot)$	أكبر قيمة ذاتية	للمصفوفات المتماثلة شبه الموجبة
$A^\top A$	مصفوفة غرام = $n \times n$ متماثلة شبه موجبة التحديد	قيمها الذاتية σ_i^2
$AA^\top$	نظيرتها $m \times m$	لها القيم الذاتية غير الصفرية نفسها
$\|A\|_1$	ناظم المشغّل لـ ℓ_1 للناظم	أكبر مجموع عمود بالمقياس المطلق
a_{ij}	العنصر في الصف i والعمود j	المدخلات الخام للمصفوفة
$\sum_i \|a_{ij}\|$	مجموع العمود j بالمقياس المطلق	نُعظّم على j
$\|A\|_\infty$	ناظم المشغّل لـ ℓ_∞ للناظم	أكبر مجموع صف بالمقياس المطلق
$\|A\|_F$	الناظم الفروبنيوسي	ليس ناظم مشغّل؛ هو ناظم شاتن S_2
$\operatorname{tr}(\cdot)$	الأثر (trace) = مجموع القطر	$\operatorname{tr}(A^\top A) = \sum_{ij} a_{ij}^2$
$\sum_i \sigma_i^2$	مجموع مربّعات القيم المفردة	$\|A\|_F^2$ = (متطابقة أساسية)

نظرية (التوافق والتضاعف التحتي).

لكل ناظم مستحث، وللمصفوفات المتوافقة الأبعاد:

$$\|Ax\|_\beta \le \|A\|_{\alpha\to\beta}\,\|x\|_\alpha, \qquad \|AB\| \;\le\; \|A\|\,\|B\| \tag{21.5}$$

وللناظم الفروبنيوسي تحديداً (وهو ليس ناظم مشغّل لكنه متوافق):

$$\|AB\|_F \le \|A\|_F \, \|B\|_F, \qquad \|AB\|_F \le \|A\|_2 \, \|B\|_F, \qquad \|AB\|_F \le \|A\|_F \, \|B\|_2 \tag{21b.5}$$

جدول رموز (21.5):

الرمز	المعنى	ملاحظات
$\|Ax\|_\beta \le \|A\|\|x\|_\alpha$	**التوافق** (consistency)	الناظم «يضبط» سلوك المشغّل
AB	جداء المصفوفتين = تركيب المشغّلين	يتطلّب توافق الأبعاد
$\|AB\| \le \|A\|\|B\|$	**التضاعف التحتي** (submultiplicativity)	أهم خاصية في هذا القسم
«لكل ناظم مستحث»	تشمل $\|\cdot\|_1$, $\|\cdot\|_2$, $\|\cdot\|_\infty$	ولا تشمل $\|\cdot\|_{\max}$ (أقصى إحداثي)
$\|\cdot\|_{\max}$	ناظم أقصى إحداثي مطلق	**ليس** متضاعفاً تحتياً — تحذير مهم
الأولى (21b.5)	تضاعف تحتي للفرونيوسي	$\|AB\|_F \le \|A\|_F \|B\|_F$
الثانية والثالثة (21b.5)	صيغ «مختلطة» أحكم	$\|AB\|_F \le \min\{\|A\|_2\|B\|_F,\ \|A\|_F\|B\|_2\}$
$\|\cdot\|_2$ في (21b.5)	الناظم الطيفي	هو الأصغر غالباً $\Longrightarrow$ الصيغة المختلطة أحكم

نظرية (نصف القطر الطيفي وصيغة غيلفاند).

ليكن $A \in \mathbb{R}^{n\times n}$ بقيم ذاتية $\lambda_1, \dots, \lambda_n$ **ونصف قطر طيفي** $\rho(A) = \max_i |\lambda_i|$. عندئذٍ:

$$\rho(A) \;=\; \lim_{k\to\infty} \left\|A^k\right\|^{1/k} \;=\; \inf_{k\ge 1} \left\|A^k\right\|^{1/k} \qquad \rho(A) \;\le\; \|A\| \quad \text{لكل ناظم مستحث}, \tag{22.5}$$

جدول رموز (22.5):

الرمز	المعنى	ملاحظات
$\rho(A)$	نصف القطر الطيفي = أكبر قيمة ذاتية بالمقياس المطلق	$\max_i \lvert\lambda_i\rvert$
λ_i	القيم الذاتية لـ A	قد تكون مركّبة
$\|A\|$	**أي** ناظم مستحث	العلاقة $\rho \le \|A\|$ عالمية
$\le$	نصف القطر أصغر من الناظم دائماً	الفجوة قد تكون كبيرة للمصفوفات غير الطبيعية
A^k	القوة الـ k للمصفوفة	A مضروبة في نفسها k مرة
$\|A^k\|^{1/k}$	الجذر الـ k لناظم القوة	يقترب من $\rho(A)$ تنازلياً
$\lim_{k\to\infty}$	نهاية المتتالية	صيغة غيلفاند (Gefland)
$\inf_{k\ge1}$	الحدّ الأدنى على كل k	يعطي تقديراً **من فوق** لـ ρ بـ k محدود
«غير طبيعية»	$A^\top A \ne AA^\top$	هنا تكون الفجوة $\rho \ll \|A\|$ كبيرة

نظرية (متراجحات تقاطعية بين النواظم المصفوفية).

لكل $A \in \mathbb{R}^{m\times n}$ برتبة r:

$$\|A\|_2 \;\le\; \sqrt{\|A\|_1 \, \|A\|_\infty} \;\le\; \sqrt{mn}\, \|A\|_{\max}, \qquad \|A\|_2 \;\le\; \|A\|_F \;\le\; \sqrt{r}\, \|A\|_2 \tag{23.5}$$

جدول رموز (23.5):

الرمز	المعنى	ملاحظات
$\sqrt{\|A\|_1\|A\|_\infty}$	حدّ تقاطعي رخيص على الناظم الطيفي	يحسب بجمع الأعمدة والصفوف فقط
$\|A\|_{\max}$	ناظم أقصى عنصر مطلق $= \max_{ij}\lvert a_{ij}\rvert$	أرخص ناظم حسابياً
$\sqrt{mn}$	الجذر التربيعي لجداء البُعدين	يظهر في الحدّ بـ $\|A\|_{\max}$؛ محكَم لمصفوفة كل عناصرها متساوية
$r = \operatorname{rank}(A)$	رتبة المصفوفة	$r \le \min(m,n)$
$\sqrt{r}$	معامل التحويل من الطيفي إلى الفرونيوسي	محكَم: يتحقّق عندما تتساوى القيم المفردة غير الصفرية
الفائدة العملية	حساب $\|A\|_2$ يحتاج SVD؛ الحدّ التقاطعي يحتاج $\mathcal{O}(nnz)$	حاسم للمصفوفات الضخمة

نظرية (متسلسلة نيومان وحدّ المعكوس).

إن كان $\|A\| < 1$ لناظم مستحث، فإن $I - A$ قابلة للعكس و:

$$(I-A)^{-1} = \sum_{k=0}^{\infty} A^k, \qquad \left\|(I-A)^{-1}\right\| \le \frac{1}{1-\|A\|} \tag{24.5}$$

جدول رموز (24.5):

الرمز	المعنى	ملاحظات
I	مصفوفة الوحدة	—
$I - A$	المصفوفة المراد عكسها	تظهر في كل مكان: معادلات تكرارية، أنظمة ديناميكية
$(I-A)^{-1}$	معكوسها	—
$\sum_{k=0}^{\infty} A^k$	متسلسلة نيومان = نظير المتسلسلة الهندسية للمصفوفات	تتقارب ffi $\rho(A) < 1$
$A^0 = I$	الحدّ الأول	—
$\|A\| < 1$	شرط كافٍ (أقوى من $\rho(A) < 1$)	مضمون بالناظم، أسهل تحقّقاً
$1/(1-\|A\|)$	حدّ على ناظم المعكوس	ينفجر عندما $\|A\| \to 1$
$1 - \|A\|$	«الهامش»	الفجوة عن الانفراد

نظرية (رقم الحالة وحساسية الحل).

ليكن A قابلة للعكس. رقم الحالة (بالناظم $\|\cdot\|$) والحساسية النسبية:

$$\kappa(A) = \|A\|\,\|A^{-1}\| \ge 1, \qquad \frac{\|\Delta x\|}{\|x\|} \le \kappa(A)\,\frac{\|\Delta b\|}{\|b\|}, \qquad \kappa_2(A) = \frac{\sigma_1}{\sigma_{\min}} \tag{25.5}$$

جدول رموز (25.5):

الرمز	المعنى	ملاحظات
$\kappa(A)$	رقم الحالة (condition number)	دائماً ≥ 1
$\|A^{-1}\|$	ناظم المعكوس	= «أدنى تمديد» مقلوباً: $1/\sigma_{\min}$ للناظم الطيفي
$\kappa \ge 1$	يتبع من $1 = \|I\| = \|AA^{-1}\| \le \|A\|\|A^{-1}\|$	—
Δx	الخطأ في الحل	$Ax = b$ يحلّ x
Δb	الاضطراب في الطرف الأيمن	—
$\frac{\|\Delta x\|}{\|x\|}$	الخطأ النسبي في الحل	المقدار المهم عملياً
$\frac{\|\Delta b\|}{\|b\|}$	الاضطراب النسبي في البيانات	—
$\kappa_2(A) = \sigma_1/\sigma_{\min}$	رقم الحالة الطيفي	المقياس القياسي لسوء التكييف
$\sigma_{\min}$	أصغر قيمة مفردة	اقترابها من الصفر $\Rightarrow$ انفجار رقم الحالة

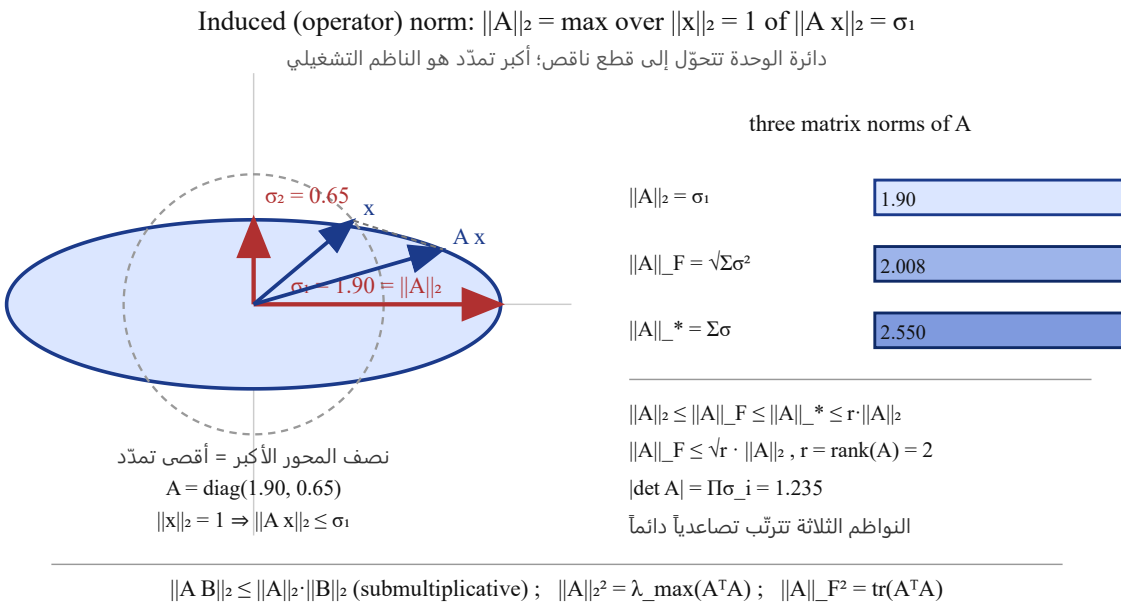
الشكل الهندسي: دائرة الوحدة تتحوّل إلى قطع ناقص، ونصف محوره الأكبر هو $\|A\|_2$:

2.4.5 البرهان

برهان $\|A\|_2 = \sigma_1$ في (20.5).

لناظم المشغّل الإقليدي:

$$\|A\|_2^2 = \max_{\|x\|_2=1} \|Ax\|_2^2 = \max_{x\neq 0} \frac{x^\top A^\top A\, x}{x^\top x}$$



شكل ٤.٥: *
الناظم المستحث هندسياً: دائرة الوحدة إلى قطع ناقص

وهذا بالضبط خارجُ قسمة رايلي للمصفوفة المتماثلة $A^\top A$؛ وبتوصيف رايلي–ريتز (انظر الفصل الرابع، (24.4)–(26.4)) قيمته القصوى هي $\lambda_{\max}(A^\top A)$. وحسب تعريف القيم المفردة $\sigma_i = \sqrt{\lambda_i(A^\top A)}$، نجد $\|A\|_2 = \sigma_1$. ■

برهان $\|A\|_1 = \max_j \sum_i |a_{ij}|$.

من متراجحة المثلث:

$$\|Ax\|_1 = \sum_i \Big|\sum_j a_{ij}x_j\Big| \le \sum_i \sum_j |a_{ij}||x_j| = \sum_j |x_j| \underbrace{\sum_i |a_{ij}|}_{\le C} \le C \sum_j |x_j| = C\|x\|_1$$

حيث $C = \max_j \sum_i |a_{ij}|$، فـ $\|A\|_1 \le C$. ولإثبات العكس نختار $x = e_{j^\star}$ عند العمود الأكبر: $\|Ae_{j^\star}\|_1 = \sum_i |a_{ij^\star}| = C$ و $\|e_{j^\star}\|_1 = 1 \Rightarrow \|A\|_1 \ge C$. ■

برهان $\|A\|_\infty$ بالتناظر

(نعكس دور الصفوف والأعمدة، أو نُطبّق النتيجة السابقة على $A^\top$ مع ملاحظة $\|A\|_\infty = \|A^\top\|_1$). ■

برهان التضاعف التحتي (21.5).

من التوافق مرّتين: $\|Bx\| \le \|B\|\,\|x\|$ و $\|ABx\| \le \|A\|\,\|Bx\|$. وبالتعظيم على $\|x\| = 1$: $\|AB\| \le \|A\|\,\|B\|$. ■

برهان $\rho(A) \le \|A\|$ في (22.5).

ليكن λ قيمة ذاتية أكبر بالمقياس المطلق و v متجهها الذاتي ($Av = \lambda v$، $v \neq 0$). من التوافق:

$$\rho(A)\,\|v\| \;=\; |\lambda|\,\|v\| \;=\; \|\lambda v\| \;=\; \|Av\| \;\le\; \|A\|\,\|v\|$$

وبالقسمة على $\|v\| > 0$: $\rho(A) \le \|A\|$. ■

برهان متسلسلة نيومان (24.5).

المجموع الجزئي $S_K = \sum_{k=0}^{K} A^k$ يحقّق $(I - A)S_K = I - A^{K+1}$. وبالتضاعف التحتي $\|A^{K+1}\| \le \|A\|^{K+1} \to 0$ لأن $\|A\| < 1$؛ فـ $S_K \to (I - A)^{-1}$، و:

$$\left\|(I - A)^{-1}\right\| \;\le\; \sum_{k=0}^{\infty} \|A\|^k \;=\; \frac{1}{1 - \|A\|} \qquad \blacksquare$$

برهان $\|A\|_2 \le \sqrt{\|A\|_1 \|A\|_\infty}$ في (23.5).

من (22.5) مطبّقاً على المصفوفة المتماثلة $A^\top A$:

$$\|A\|_2^2 \;=\; \rho(A^\top A) \;\le\; \|A^\top A\|_\infty \;\le\; \|A^\top\|_\infty\,\|A\|_\infty \;=\; \|A\|_1\,\|A\|_\infty$$

حيث استخدمنا $\|A^\top\|_\infty = \|A\|_1$. ■

برهان (25.5).

من $Ax = b$ و $A(x + \Delta x) = b + \Delta b$ نجد $A\Delta x = \Delta b$ فـ $\Delta x = A^{-1}\Delta b$؛ إذن $\|\Delta x\| \le \|A^{-1}\|\,\|\Delta b\|$. ومن $b = Ax$: $\|b\| \le \|A\|\,\|x\|$ فـ $\frac{1}{\|x\|} \le \frac{\|A\|}{\|b\|}$. بضرب المتراجحتين:

$$\frac{\|\Delta x\|}{\|x\|} \;\le\; \|A^{-1}\|\,\|\Delta b\| \cdot \frac{\|A\|}{\|b\|} \;=\; \kappa(A)\,\frac{\|\Delta b\|}{\|b\|} \qquad \blacksquare$$

تنبيه: الناظم الفروبينيوسي **ليس** ناظم مشغّل: $\|A\|_F \neq \max_{\|x\|_2=1} \|Ax\|_2$ (مثال: $A = I_n$ يعطي $\|I\|_F = \sqrt{n}$ في حين أن $\|I\|_2 = 1$). ومع ذلك فهو **متوافق**: $\|Ax\|_2 \le \|A\|_F \|x\|_2$، ويحقّق التضاعف التحتي (21b.5). وكذلك ناظم أقصى عنصر $\|A\|_{\max}$ **ليس** متضاعفاً تحتياً: مثال $A = B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ يعطي $\|A\|_{\max}\|B\|_{\max} = 1$ في حين أن $\|AB\|_{\max} = 2 > 1$.

3.4.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-4.5): الناظم الطيفي لطبقة خطية بوصفه ثابت ليبشيتز

المعطيات: مصفوفة أوزان $A = \begin{pmatrix} 1.2 & -0.4 \\ 0.6 & 1.1 \end{pmatrix}$.

المطلوب: احسب $\|A\|_2$ و $\|A\|_F$ وتحقّق من $\|A\|_2 \le \|A\|_F \le \sqrt{r}\|A\|_2$.

الحل:

١. $A^\top A = \begin{pmatrix} 1.44+0.36 & -0.48+0.66 \\ -0.48+0.66 & 0.16+1.21 \end{pmatrix} = \begin{pmatrix} 1.80 & 0.18 \\ 0.18 & 1.37 \end{pmatrix}$.

٢. الأثر $= 3.17$ والمحدِّد $= 1.80 \times 1.37 - 0.18^2 = 2.466 - 0.0324 = 2.4336$.

٣. القيمتان الذاتيتان: $\lambda = \dfrac{3.17 \pm \sqrt{10.0489 - 9.7344}}{2} = \dfrac{3.17 \pm 0.5608}{2}$، أي $\lambda_1 = 1.8654$ و $\lambda_2 = 1.3046$.

٤. القيمتان المفردتان: $\sigma_1 = \sqrt{1.8654} = 1.3658$ و $\sigma_2 = \sqrt{1.3046} = 1.1422$. إذن $\|A\|_2 = 1.3658$.

٥. $\|A\|_F = \sqrt{1.44 + 0.16 + 0.36 + 1.21} = \sqrt{3.17} = 1.7804$.

٦. التحقّق: $1.3658 \le 1.7804 \le \sqrt{2} \times 1.3658 = 1.9315$ ✓.

النتيجة: $\|A\|_2 = 1.3658$ و $\|A\|_F = 1.7804$.

الربط بالذكاء الاصطناعي: $\|A\|_2$ هو بالضبط **ثابت ليبشيتز** للطبقة الخطية: $\|Ax_1 - Ax_2\|_2 \le 1.3658\|x_1 - x_2\|_2$. ومع تفعيل ReLU (ذي ثابت ليبشيتز 1) يبقى ثابت الطبقة المركّبة 1.3658. سلسلة طبقات كهذه يُضرب ثوابتها — وهذا هو المبدأ الذي تقوم عليه الشبكات مقيَّدة ليبشيتز (Lipschitz networks) والتحقّق الرسمي من المتانة.

مثال (5.4-2): نواظم الصفوف والأعمدة والحدّ التقاطعي الرخيص على الناظم الطيفي

المعطيات: $A = \begin{pmatrix} 0.5 & -0.3 & 0.7 \\ -0.2 & 0.9 & 0.1 \\ 0.4 & 0.2 & -0.6 \end{pmatrix}$.

المطلوب: احسب $\|A\|_1$ و $\|A\|_\infty$ و $\|A\|_F$، واستخرج حدّاً على $\|A\|_2$ without SVD، ثم حدّاً أدنى له.

الحل:

١. مجاميع الأعمدة (مطلقة): $c_1 = 0.5 + 0.2 + 0.4 = 1.1$؛ $c_2 = 0.3 + 0.9 + 0.2 = 1.4$؛ $c_3 = 0.7 + 0.1 + 0.6 = 1.4$. $\Rightarrow \|A\|_1 = 1.4$.

٢. مجاميع الصفوف (مطلقة): $r_1 = 0.5 + 0.3 + 0.7 = 1.5$؛ $r_2 = 0.2 + 0.9 + 0.1 = 1.2$؛ $r_3 = 0.4 + 0.2 + 0.6 = 1.2$. $\Rightarrow \|A\|_\infty = 1.5$.

٣. $\|A\|_F = \sqrt{0.25 + 0.09 + 0.49 + 0.04 + 0.81 + 0.01 + 0.16 + 0.04 + 0.36} = \sqrt{2.25} = 1.5$.

٤. الحدّ التقاطعي (5.3-2): $\|A\|_2 \le \sqrt{1.4 \times 1.5} = \sqrt{2.10} = 1.4491$ — وهو **أحكم** من $\|A\|_F = 1.5$.

٥. حدّ أدنى: $\|A\|_2 = \|A^\top\|_2 \ge \max_i \|(A^\top)e_i\|_2 = \max_i$ (ناظم الصف i) $= \max(0.9110,\ 0.9274,\ 0.7483) = 0.9274$. $= \max(\sqrt{0.83}, \sqrt{0.86}, \sqrt{0.56})$.

٦. إذن $\|A\|_2 \in [0.9274,\ 1.4491]$.

النتيجة: $\|A\|_1 = 1.4$، $\|A\|_\infty = 1.5$، $\|A\|_F = 1.5$، و $\|A\|_2 \in [0.9274,\ 1.4491]$.
الربط بالذكاء الاصطناعي: حساب SVD لمصفوفة 4096×4096 مكلِف، أمّا $\|A\|_1$ و $\|A\|_\infty$ فمجرد مجاميع على الأعمدة والصفوف — تكلفة $\mathcal{O}(nnz)$ وتعمل على مصفوفات متناثرة ضخمة. حدّ (23.5) هو الأداة اليومية لتقدير سريع للناظم الطيفي في التطبيع الطيفي التقريبي (approximate spectral normalization) وفي مراقبة استقرار التدريب.

مثال (4.5-3): التضاعف التحتي على سلسلة طبقتين — كم هو فضفاض الحدّ؟

المعطيات: $W_1 = \begin{pmatrix} 1.5 & 0 \\ 0 & 2.1 \end{pmatrix}$ و $W_2 = \begin{pmatrix} 1.7 & 0 \\ 0 & 0.3 \end{pmatrix}$.
المطلوب: قارن $\|W_2 W_1\|_2$ الفعلي بجداء النواظم الطيفية وبجداء النواظم الفرونيوسية.
الحل:

١. $\|W_1\|_2 = 2.1$ و $\|W_2\|_2 = 1.7$ (مصفوفتان قطريتان: القيم المفردة على القطر).

٢. جداء النواظم الطيفية (الحدّ): $\|W_2 W_1\|_2 \le 1.7 \times 2.1 = 3.57$.

٣. القيمة الفعلية: $W_2 W_1 = \begin{pmatrix} 2.55 & 0 \\ 0 & 0.63 \end{pmatrix} \Rightarrow \|W_2 W_1\|_2 = 2.55$.

٤. النواظم الفرونيوسية: $\|W_1\|_F = \sqrt{2.25 + 4.41} = \sqrt{6.66} = 2.5807$، $\|W_2\|_F = \sqrt{2.89 + 0.09} = \sqrt{2.98} = 1.7263$؛ الحدّ $= 4.4551$.

٥. $\|W_2 W_1\|_F = \sqrt{6.5025 + 0.3969} = \sqrt{6.8994} = 2.6266$.

٦. الترتيب: 2.55 (فعلي) ≤ 3.57 (طيفي) ≤ 4.4551 (فرونيوسي).

النتيجة: حدّ النواظم الطيفية فضفاض بمعامل $3.57/2.55 = 1.40$؛ وحدّ الفرونيوسية بمعامل $4.4551/2.55 = 1.75$.
الربط بالذكاء الاصطناعي: الحدّ فضفاض هنا لأن الاتجاه الذي يمدّده W_1 أكثر ما يمكن (المحور الثاني) ليس الاتجاه الذي يمدّده W_2 أكثر ما يمكن (المحور الأول) — أي أن القيم المفردة «غير متوازية». في الشبكات العميقة، جداء النواظم الطيفية عبر الطبقات قد يكون فضفاضاً بمراتب، وهذا بالضبط ما يجعل «التحقّق الرسمي» متحفّظاً مقارنة بالمتانة الفعلية. لكنه الحدّ الوحيد المضمون **بلا فحص للتركيب**، ولهذا يُستخدم في الشهادات.

مثال (4.5-4): نصف القطر الطيفي مقابل الناظم الطيفي — النمو العابر في الشبكات التكرارية

المعطيات: مصفوفة انتقال حالة تكرارية $A = \begin{pmatrix} 0.9 & 1.0 \\ 0 & 0.9 \end{pmatrix}$.
المطلوب: احسب $\rho(A)$ و $\|A\|_2$، ثم بيّن أن $\|A^k\|$ قد ينمو أولاً ثم يزول رغم أن $\rho(A) < 1$.
الحل:

١. القيم الذاتية (مثلثية): $\rho(A) = 0.9 < 1 \implies \lambda_1 = \lambda_2 = 0.9$. $A^k \to 0$.

٢. $A^\top A = \begin{pmatrix} 0.81 & 0.9 \\ 0.9 & 1.81 \end{pmatrix}$؛ الأثر $= 2.62$، المحدِّد $= 0.81 \times 1.81 - 0.81 = 0.6561$.

٣. $\|A\|_2 = \sqrt{\lambda_1}$، $\lambda_1 = 2.3396 \implies \lambda = \dfrac{2.62 \pm \sqrt{6.8644 - 2.6244}}{2} = \dfrac{2.62 \pm 2.0591}{2}$
$\sqrt{2.3396} = 1.5296$.

٤. الفجوة: $\|A\|_2 = 1.5296 > \rho(A) = 0.9$ بمعامل 1.70 — لأن A **غير طبيعية**.

٥. القوى: $A^k = \begin{pmatrix} 0.9^k & k\,0.9^{k-1} \\ 0 & 0.9^k \end{pmatrix}$. عند $k = 5$: $A^5 = \begin{pmatrix} 0.5905 & 3.2805 \\ 0 & 0.5905 \end{pmatrix}$ وناظمه الفروبنيوسي $= \sqrt{0.3487 + 10.7617 + 0.3487} = \sqrt{11.4591} = 3.385$ — **أكبر من $\|A\|_2$ نفسه!**

٦. ثم يزول: عند $k = 20$: $0.9^{20} = 0.1216$، و $20 \times 0.9^{19} = 2.7018$، فـ $\|A^{20}\|_F \approx 2.707$ — في طريقه إلى الصفر.

النتيجة: $\rho(A) = 0.9$ (مستقر نهائياً)، لكن $\|A^5\| \approx 3.38$ — **نمو عابر** بمعامل يقارب 3.8 قبل الزوال.

الربط بالذكاء الاصطناعي: هذه هي الرياضيات الدقيقة لظاهرتَي **انفجار وتلاشي التدرّج** في RNN. الشرط الصحيح للاستقرار النهائي هو $\rho(A) < 1$ لا $\|A\| < 1$؛ لكن النمو العابر (transient growth) الناشئ عن عدم الطبيعية (non-normality) هو ما يجعل التدريب فعلياً غير مستقر رغم الاستقرار النظري. ولهذا تُستخدم **الوحدوية** (orthogonal/unitary RNN) التي تجعل $\|A\|_2 = 1$ وتمنع النمو العابر تماماً.

مثال (5-4.5): تقدير نصف القطر الطيفي بصيغة غيلفاند

المعطيات: $A = \begin{pmatrix} 0.8 & 1.0 \\ 0 & 0.4 \end{pmatrix}$.

المطلوب: احسب $\rho(A)$ بالتحليل، ثم قدّره بـ $\|A^k\|^{1/k}$ عند $k = 1, 2, 4, 8$ وتحقّق من التناقص نحو ρ.

الحل:

١. القيم الذاتية (مثلثية): 0.8 و $0.4 \implies \rho(A) = 0.8$.

٢. شكل القوى: $A^k = \begin{pmatrix} 0.8^k & c_k \\ 0 & 0.4^k \end{pmatrix}$ حيث $c_k = \dfrac{0.8^k - 0.4^k}{0.8 - 0.4}$.

٣. $k = 1$: $c_1 = 1.0$؛ $\|A\|_F = \sqrt{0.64 + 1 + 0.16} = \sqrt{1.80} = 1.3416 \implies \|A\|_F^{1/1} = 1.3416$.

٤. $k = 2$: $c_2 = \dfrac{0.64 - 0.16}{0.4} = 1.2$؛ $\|A^2\|_F = \sqrt{0.4096 + 1.44 + 0.0256} = \sqrt{1.8752} = 1.3694 \implies 1.1702^{1/2}$.

٥. $k = 4$: $c_4 = \dfrac{0.4096 - 0.0256}{0.4} = 0.96$؛ $\|A^4\|_F = \sqrt{0.16777 + 0.9216 + 0.000655} = \sqrt{1.09003} = 1.0440 \implies 1.0108^{1/4}$.

٦. $k = 8$: $\|A^8\|_F = \sqrt{0.02814 + 0.17455 + 4.3 \times 10^{-7}} = \sqrt{0.20269} = 0.4502$، $c_8 = \dfrac{0.16777 - 0.000655}{0.4} = 0.41779$؛ $\Longrightarrow 0.9051 = 0.4502^{1/8}$.

٧. المتتالية: $0.8 \to 0.9051 \to \cdots \to 1.0108 \to 1.1702 \to 1.3416$، وهي **متناقصة** وتفوق $\rho = 0.8$ دائماً (inf يعطي حداً من فوق).

النتيجة: $\rho(A) = 0.8$، وأفضل تقدير بـ k محدود هو 0.9051 عند $k = 8$ (خطأ $+13\%$).

الربط بالذكاء الاصطناعي: صيغة غيلفاند هي الأداة العملية لفحص استقرار الأنظمة الديناميكية المُتعلَّمة (Neural ODE)، الشبكات التكرارية العميقة، (equilibrium models) حين لا نريد حساب القيم الذاتية: نحسب ناظم قوةٍ عالية A^{2^j} (بالتكرير المتكرّر) ونأخذ الجذر. ولأن المتتالية متناقصة، فكل تقدير هو **حدّ أعلى مضمون** — أي أن الفحص «متحفّظ دائماً» ولا يعلن الاستقرار زوراً.

مثال (5.4-6): متسلسلة نيومان في طبقة ضمنية (implicit layer)

المعطيات: طبقة ضمنية تُعرَّف بالعلاقة $x = Ax + b$ حيث $A = \begin{pmatrix} 0.4 & 0.3 \\ -0.3 & 0.4 \end{pmatrix}$، و b ثابت. الحل $x^\star = (I - A)^{-1}b$ يُحسب تكرارياً: $x_{k+1} = Ax_k + b$ ببداية $x_0 = b$، و $\|x_1 - x_0\| = 1$.

المطلوب: حدّ على $\|(I - A)^{-1}\|_2$، والقيمة الدقيقة، وعدد التكرارات اللازمة لدقة 10^{-4}.

الحل:

١. نلاحظ أن عمودَي A متعامدان متساويا الطول: $A^\top A = 0.25\, I \Longrightarrow \sigma_1 = \sigma_2 = 0.5 \Longrightarrow \|A\|_2 = 0.5 < 1$ ✓ (شرط نيومان متحقّق).

٢. حدّ نيومان: $\|(I - A)^{-1}\|_2 \le \dfrac{1}{1 - 0.5} = 2.0$.

٣. القيمة الدقيقة: $I - A = \begin{pmatrix} 0.6 & -0.3 \\ 0.3 & 0.6 \end{pmatrix}$، و $(I - A)^\top (I - A) = 0.45\, I \Longrightarrow$ قيمه المفردة كلها $\sqrt{0.45} = 0.67082$ $\Longrightarrow \|(I - A)^{-1}\|_2 = 1/0.67082 = 1.4907$.

٤. التحقّق: $1.4907 \le 2.0$ ✓ (الحدّ صحيح وفضفاض بمعامل 1.34).

٥. عدد التكرارات: $\|x_k - x^\star\| \le \dfrac{\|A\|^k}{1 - \|A\|}\|x_1 - x_0\| = 2 \times 0.5^k$. نحتاج $2 \times 0.5^k \le 10^{-4} \Longrightarrow 0.5^k \le 5 \times 10^{-5}$ $\Longrightarrow k \ge \log_2(2 \times 10^4) = 14.29 \Longrightarrow k = 15$.

النتيجة: $\|(I - A)^{-1}\|_2 = 1.4907 \le 2.0$، ونحتاج 15 تكراراً لدقة 10^{-4}.

الربط بالذكاء الاصطناعي: الطبقات الضمنية (implicit layers)، DEQ (equilibrium models) تحلّ بالضبط معادلةً من هذا النوع، وشرط تقاربها $\|A\| < 1$ هو نفسه شرط متسلسلة نيومان. حدّ $\frac{1}{1-\|A\|}$ يخبرنا أيضاً بسلوك التدرّج: $\frac{\partial x^\star}{\partial b} = (I - A)^{-1}$، فاقتراب $\|A\|$ من 1 يجعل التدرّج ينفجر — ولهذا تُقيَّد هذه النماذج بتطبيع طيفي صريح.

مثال (5.4-7): رقم الحالة وحساسية المربّعات الصغرى

المعطيات: $A = \begin{pmatrix} 1 & 1 \\ 1 & 1.01 \end{pmatrix}$، ونريد حلّ $Ax = b$.

المطلوب: احسب القيمتين المفردتين و $\kappa_2(A)$، ثم قدّر أسوأ خطأ نسبي في الحل عند اضطراب نسبي مقداره 10^{-3} في b.

الحل:

١. $\det A = 1 \times 1.01 - 1 \times 1 = 0.01$؛ و $\|A\|_F^2 = 1 + 1 + 1 + 1.0201 = 4.0201$.

٢. من $\sigma_1\sigma_2 = |\det A| = 0.01$ و $\sigma_1^2 + \sigma_2^2 = 4.0201$: نضع $\sigma_2 = 0.01/\sigma_1$ فنحصل $\sigma_1^2 + 10^{-4}/\sigma_1^2 = 4.0201 \Longrightarrow \sigma_1^2 \approx 4.020075 \Longrightarrow \sigma_1 = 2.00501$، و $\sigma_2 = 0.01/2.00501 = 0.0049875$.

٣. رقم الحالة: $\kappa_2(A) = \dfrac{2.00501}{0.0049875} = 402.0$.

٤. الحساسية (5.25): $\dfrac{\|\Delta x\|}{\|x\|} \le 402.0 \times 10^{-3} = 0.402$.

٥. المقارنة بمصفوفة حسنة التكييف: $\kappa_2 = 1 \Longrightarrow \sigma_1 = \sigma_2 = \sqrt{2} \Longrightarrow A'^{\top}A' = 2I \Longrightarrow A' = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$ $\Longrightarrow$ الخطأ النسبي $\le 10^{-3}$.

النتيجة: $\kappa_2(A) = 402$ — أي أن خطأً نسبياً مقداره 0.1% في البيانات قد يُنتج خطأً نسبياً حتى 40% في الحل.

الربط بالذكاء الاصطناعي: سوء التكييف هو سبب رئيسي لعدم استقرار تدريب الشبكات: مصفوفات الغرام $X^{\top}X$ ذات الميزات المترابطة تكون سيّئة التكييف، فتتضخّم التحديثات في اتجاهات القيم الذاتية الصغيرة. العلاجات الثلاثة الشائعة — التنظيم (يزيد $\sigma_{\min}$ فعلياً)، وتطبيع الدفعات/الطبقات (يُحسّن تكييف ميزات المدخل)، و Adam (يقيس التحديثات بمقياس متوازن) — هي جميعاً استجابات لرقم الحالة.

مثال (5.4-8): حدّ تقاطعي رخيص للناظم الطيفي في طبقة ضخمة 4096×512

المعطيات: طبقة $W \in \mathbb{R}^{4096\times 512}$، أكبر مجموع عمود $\|W\|_1 = 12.4$، وأكبر مجموع صف $\|W\|_\infty = 1.8$، وأكبر عنصر مطلق $\|W\|_{\max} = 0.05$.

المطلوب: قدّر $\|W\|_2$ بالحدّين في (5.23) وقارن.

الحل:

١. الحدّ التقاطعي (صفوف/أعمدة): $\|W\|_2 \le \sqrt{12.4 \times 1.8} = \sqrt{22.32} = 4.7246$.

٢. حدّ أقصى عنصر: $\|W\|_2 \le \sqrt{mn}\,\|W\|_{\max} = \sqrt{4096 \times 512} \times 0.05 = \sqrt{2097152} \times 0.05 = 1448.15 \times 0.05 = 72.41$.

٣. نأخذ الأحكم (الأصغر): $\|W\|_2 \le 4.7246$ — وهو أحكم من حدّ أقصى عنصر بـ $72.41/4.7246 = 15.3$ مرة.

٤. التكلفة: الحدّان معاً يحتاجان مجاميع على الصفوف والأعمدة وإيجاداً لأكبر عنصر — كلها $\mathcal{O}(mn)$ أو $\mathcal{O}(nnz)$، مقابل $\mathcal{O}\big(mn\min(m,n)\big)$ لـ SVD كاملة — أي توفير بمراتب.

٥. ملاحظة: لا يسود أحد الحدّين الآخر دائماً. حدّ أقصى عنصر يسود إذا كانت العناصر صغيرة ومتساوية المقدار؛ والحدّ التقاطعي يسود إذا تركّز الناظم في صفوف أو أعمدة قليلة سميكة (كما في هذه الحالة: مجموع عمود يبلغ 12.4 مع عنصر أعظمي 0.05 يعني عموداً كثيفاً).

النتيجة: $\|W\|_2 \le 4.7246$ بالحدّ التقاطعي، و ≤ 72.41 بحدّ أقصى عنصر، نأخذ الأحكم: 4.7246.

الربط بالذكاء الاصطناعي: القاعدة العملية: **احسب الحدّين وخذ الأحكم.** لا أحدهما يسود الآخر دائماً: حدّ أقصى عنصر يسود حين تكون العناصر متساوية المقدار تقريباً، والحدّ التقاطعي يسود حين يتركّز الناظم في صفوف/أعمدة قليلة سميكة. هذه الحدود الرخيصة تُستخدم في «التطبيع الطيفي بقوة واحدة» spectral (power-iteration norm) وفي مراقبة تضخّم الناظم أثناء التدريب بتكلفة لا تُذكر.

مثال (5.4-9): القصّ بالفرونيوسي مقابل الطيفي — كم يتغيّر ثابت ليبشيتز فعلاً؟

المعطيات: تدرّج $G \in \mathbb{R}^{256\times 128}$ بـ $\|G\|_F = 3.4$ و $\|G\|_2 = 0.9$؛ معدّل تعلّم η. التحديث $\Delta W = -\eta\, G$ مقصوص بشرط $\|\Delta W\|_F \le 1.0$.

المطلوب: حدّ على التغيّر في الناظم الطيفي للطبقة (أي في ثابت ليبشيتز) بعد التحديث، ومقارنته بالقيمة النموذجية.

الحل:

١. التحقّق من الترتيب: $\|G\|_2 = 0.9 \le \|G\|_F = 3.4 \le \sqrt{128}\times 0.9 = 10.18$ ✓ $(r \le 128)$.

٢. بعد القصّ إلى $\|\Delta W\|_F \le 1.0$: معامل القصّ $= 1.0/(\eta \times 3.4)$؛ فالتحديث المقصوص ناظمه الطيفي $= 0.9 \times \frac{1.0}{3.4} = 0.2647$.

٣. الحدّ المضمون على التغيّر الطيفي: $\|\Delta W\|_2 \le \|\Delta W\|_F \le 1.0$ — أي أن ثابت ليبشيتز قد يتغيّر حتى 1.0.

٤. القيمة الفعلية (بافتراض أن القصّ يُبقي الاتجاه): $\|\Delta W\|_2 = 0.2647$.

٥. الفجوة بين الحدّ والقيمة: $1.0/0.2647 = 3.78$ مرة.

النتيجة: القصّ الفرونيوسي يضمن $\|\Delta W\|_2 \le 1.0$ لكنه فعلياً يُحدث تغيّراً طيفياً مقداره ≈ 0.26.

الربط بالذكاء الاصطناعي: الطبقة تتصرّف بوصفها **مشغّلاً**، فالكمية المهمة هي $\|W\|_2$ لا $\|W\|_F$. القصّ الفرونيوسي (الشائع في clip_grad_norm_) يضبط الطول بوصفه قائمة أرقام، ويترك تغيّراً غير مضبوط بدقة في ثابت ليبشيتز بمعامل حتى $\sqrt{r} \approx 11$. حين يكون الاستقرار هدفاً صريحاً (تدريب خصمي، تدفّقات مقيَّدة، نماذج انتشارية)، يُستعمل القصّ أو التنظيم على الناظم الطيفي مباشرة.

مثال (10-4.5): ثابت ليبشيتز لشبكة من أربع طبقات — جداء طيفي مقابل جداء فرونيوسي

المعطيات: أربع طبقات بعرض 256: النواظم الطيفية $(1.8,\ 2.2,\ 1.5,\ 2.0)$؛ والنواظم الفرونيوسية $(18.4,\ 22.7,\ 15.2,\ 20.1)$. التفعيلات ReLU (ثابت ليبشيتز 1).

المطلوب: حدّان على ثابت ليبشيتز الشبكة كلها، ونسبة الفجوة بينهما.

الحل:

١. حدّ جداء النواظم الطيفية: $L_{\text{spec}} = 1.8 \times 2.2 \times 1.5 \times 2.0$.

- $1.8 \times 2.2 = 3.96$، $1.5 \times 2.0 = 3.0$، المجموع: $3.96 \times 3.0 = 11.88$.

١. حدّ جداء النواظم الفرونيوسية: $L_F = 18.4 \times 22.7 \times 15.2 \times 20.1$.

- $18.4 \times 22.7 = 417.68$، $15.2 \times 20.1 = 305.52$، المجموع: $417.68 \times 305.52 = 1.276 \times 10^5$.

١. نسبة الفجوة: $1.276 \times 10^5 / 11.88 = 1.074 \times 10^4$ — **أي أربعة مراتب!**

٢. التفسير: $\frac{20.1}{2.0} = 10.05$, $\frac{15.2}{1.5} = 10.1$, $\frac{22.7}{2.2} = 10.3$, $\frac{18.4}{1.8} = 10.2$ $\approx$ $\frac{\|W_i\|_F}{\|W_i\|_2}$ — كل طبقة تُدخل معاملاً ≈ 10، والمجموع 10^4.

النتيجة: $L \le 11.88$ بالحدّ الطيفي، مقابل $L \le 1.276 \times 10^5$ بالحدّ الفرونيوسي — فجوة بمراتب أربع.

الربط بالذكاء الاصطناعي: هذا المثال يوضّح لماذا يُعدّ **التطبيع الطيفي** (spectral normalization) — وهو الذي يضبط $\|W\|_2$ لكل طبقة — الأداةَ الفعّالة في WGAN والشبكات مقيَّدة ليبشيتز، بينما تنظيم $\|W\|_F$ (weight decay العادي) لا يعطي تحكّماً ذا معنى في ثابت ليبشيتز العميق. القاعدة: **للتحليل استخدم الناظم الطيفي؛ للحساب استخدم ما هو أرخص ثم حوّل.**

مثال (11-4.5): مصفوفة عشوائية الصفوف — عدم التوسّع في ℓ_∞ (تمرير الرسائل والانتباه)

المعطيات: مصفوفة انتقال $P = \begin{pmatrix} 0.6 & 0.4 & 0 \\ 0.2 & 0.5 & 0.3 \\ 0.1 & 0.1 & 0.8 \end{pmatrix}$ (صفوفها غير سالبة ومجموع كل صف $= 1$).

المطلوب: احسب $\|P\|_1$ و $\|P\|_\infty$ و $\rho(P)$، وحدّاً على $\|P\|_2$، واستنتج سلوك التطبيق المتكرّر.

الحل:

١. مجاميع الصفوف $= (1.0,\ 1.0,\ 1.0) \Longrightarrow \|P\|_\infty = 1.0$.

٢. مجاميع الأعمدة: $c_1 = 0.6+0.2+0.1 = 0.9$، $c_2 = 0.4+0.5+0.1 = 1.0$، $c_3 = 0+0.3+0.8 = 1.1$ $\Longrightarrow \|P\|_1 = 1.1$.

٣. $\rho(P) = 1$ (لكل مصفوفة عشوائية قيمة ذاتية 1 مع المتجه **1**)، والتحقّق: $\rho \le \|P\|_\infty = 1$ ✓.

٤. $\|P\|_2 \le \sqrt{1.1 \times 1.0} = 1.0488$.

٥. عدم التوسّع في ℓ_∞: $\|Px\|_\infty \le \|P\|_\infty \|x\|_\infty = \|x\|_\infty$ — كل إحداثي في الخرج هو **تركيبة محدّبة** من إحداثيات المدخل، فلا يتجاوز أكبرها.

النتيجة: تطبيق P مرّات متكرّرة لا يمكن أن يضخّم $\|\cdot\|_\infty$ — و $\rho(P) = 1$ يعني أن التوزيع يستقرّ ولا ينفجر.

الربط بالذكاء الاصطناعي: هذا هو الضمان الكامن خلف استقرار الشبكات العصبية البيانية (GNN) وطبقات الانتباه المُقنَّعة حين تكون مصفوفة الخلط عشوائية الصفوف: تمرير الرسائل يبقى **تركيبةً محدّبة** فلا تنفجر قيم العُقد مها تعمّقت الشبكة (خلافاً للابلاسيد الخام أو المصفوفات غير المُطبَّعة). وهو أيضاً سبب شيوع «التنعيم المفرط» (over-smoothing): عدم التوسّع يعني أن التطبيق المتكرّر يُقارب الإحداثيات نحو المتوسط — انهيار تدريجي لا انفجار.

مثال (5.4-12): ناظم المعكوس وأدنى تمديد — الحساسية من الجهة الأخرى

المعطيات: $A = \begin{pmatrix} 2 & 0 \\ 0 & 0.25 \end{pmatrix}$ و $b = (1, 1)^\top$ واضطراب $\Delta b = (0.01,\ 0)^\top$.

المطلوب: احسب $\|A\|_2$ و $\|A^{-1}\|_2$ و $\kappa_2(A)$، ثم قارن الخطأ النسبي الفعلي في الحل بحدّ (25.5).

الحل:

١. القيم المفردة (قطرية): $\sigma_1 = 2$، $\sigma_2 = 0.25$ $\Longrightarrow$ $\|A\|_2 = 2$.

٢. $A^{-1} = \begin{pmatrix} 0.5 & 0 \\ 0 & 4 \end{pmatrix}$ $\Longrightarrow$ قيمها المفردة $(0.5,\ 4)$ $\Longrightarrow$ $\|A^{-1}\|_2 = 4 = 1/\sigma_{\min}$ ✓.

٣. $\kappa_2(A) = 2 \times 4 = 8$.

٤. التمديد: لـ $\|x\|_2 = 1$ يقع $\|Ax\|_2$ في $[0.25,\ 2]$ — الإحداثي الثاني **يُضغط** إلى ربْع قيمته.

٥. الحل: $x = A^{-1}b = (0.5,\ 4)^\top$؛ $\|x\|_2 = \sqrt{0.25 + 16} = 4.0311$.

٦. $\Delta x = A^{-1}\Delta b = (0.005,\ 0)^\top$؛ $\|\Delta x\|_2 = 0.005$؛ الخطأ النسبي $= 0.005/4.0311 = 0.001240$.

٧. الاضطراب النسبي: $\|\Delta b\|_2/\|b\|_2 = 0.01/\sqrt{2} = 0.007071$.

٨. الحدّ: $0.001240 \ge 0.05657 = 8 \times 0.007071$ ✓ $\kappa_2 \times$ — صحيح وفضفاض بمعامل 45.6.

النتيجة: $\kappa_2 = 8$، والخطأ النسبي الفعلي 0.124% يقع تحت الحدّ المضمون 5.66%.

الربط بالذكاء الاصطناعي: $\|A^{-1}\|_2 = 1/\sigma_{\min}$ يعني أن أصغر قيمة مفردة تحدّد **أدنى تمديد**: كلّما صغُرت، صار بالإمكان «إخفاء» اضطرابات كبيرة في اتجاهها، وتضخّمت عند العكس. وفي الشبكات، اتجاهات القيم المفردة الصغيرة للجاكوبي هي اتجاهات «العمى»: المدخلات فيها لا تُحدث أثراً يُذكر في الخرج — وهي تحديداً الاتجاهات التي تستغلّها الهجمات الخصمية (حساسية عالية عند العكس، أثر ضئيل عند الأمام).

مثال (5.4-13): استقرار التوصيلات المتبقّية (residual connections) و«مقياس التوصيلة»

المعطيات: شبكة من $L = 50$ كُتَل متبقّية: $x_{l+1} = x_l + W_l x_l = (I + W_l)x_l$، بـ $\|W_l\|_2 = 0.15$ لكل l.
المطلوب: حدّ على ناظم المشغّل الكلي، وأثر إدخال مقياس تصغير α على فرع التوصيلة.
الحل:

١. لكل كتلة: $\|I + W_l\|_2 \le \|I\|_2 + \|W_l\|_2 = 1 + 0.15 = 1.15$؛ وبالمتراجحة الفرقية $\|I + W_l\|_2 \ge |1 - 0.15| = 0.85$.

٢. بالتضاعف التحتي على 50 كتلة: $\left\|\prod_l (I + W_l)\right\|_2 \le 1.15^{50}$.

٣. الحساب: $\ln(1.15) = 0.13976$، $\times 50 = 6.988$؛ $e^{6.988} = 1082$.

٤. بمقياس تصغير $\alpha = 0.1$: $\|I + \alpha W_l\|_2 \le 1 + 0.015 = 1.015$؛ و $1.015^{50} = e^{50 \times 0.014889} = e^{0.7444} = 2.105$.

٥. التحسين: $1082 / 2.105 = 514$ مرة.

النتيجة: الحدّ الأسوأ يتحسّن من 1082 إلى ≈ 2.1 بمجرّد تصغير فرع التوصيلة بمعامل 10.
الربط بالذكاء الاصطناعي: هذا هو المبرّر الرياضي المباشر لتقنيات مثل **residual / SkipInit / ReZero scaling** التي تُضاعف فرع التوصيلة بمعامل صغير قابل للتعلّم (أو تُهيّئه بالصفر): فهي تحوّل النموّ الأُسّي $(1 + \|W\|)^L$ إلى $(1 + \alpha\|W\|)^L$ القريب من 1. وبدونها، حتى ناظم طيفي صغير لكل كتلة (0.15) يُنتج انفجاراً بمعامل 10^3 بعد 50 كتلة — وهو بالضبط سبب الحاجة إلى LayerNorm/Pre-LN في المحوّلات العميقة.

مثال (5.4-14): مصفوفة الالتفاف — لماذا الناظم الطيفي مستقل عن حجم الصورة والفرونيوسي ليس كذلك؟

المعطيات: نواة التفاف 3×3: $k = \begin{pmatrix} 0.2 & -0.1 & 0.05 \\ -0.3 & 0.4 & -0.1 \\ 0.1 & -0.05 & 0.15 \end{pmatrix}$، تُطبَّق بـ «same» padding على صورة من N بكسل. المصفوفة المرافقة $C \in \mathbb{R}^{N \times N}$.
المطلوب: حدّ على $\|C\|_2$، ومقارنته بـ $\|C\|_F$، والاستنتاج.
الحل:

١. كل صف من C يحوي على الأكثر عناصر النواة التسعة $\Longrightarrow$ مجموع الصفوف المطلق $\le \sum_{ij} |k_{ij}|$.

٢. $\|C\|_\infty \le 1.45$ إذن $\sum |k| = 0.2 + 0.1 + 0.05 + 0.3 + 0.4 + 0.1 + 0.1 + 0.05 + 0.15 = 1.45$؛ وبالمثل $\|C\|_1 \le 1.45$ (كل عمود يحوي على الأكثر تسعة عناصر).

٣. من (23.5): $\|C\|_2 \le \sqrt{1.45 \times 1.45} = 1.45$ — **مستقل عن N**.

٤. $\|C\|_F$: كل صف داخلي ناظمه $\sqrt{\sum k^2} = \sqrt{0.3475} = 0.5895$، إذن $\|C\|_F \approx 0.5895\sqrt{N}$ — **ينمو مع $\sqrt{N}$**.

٥. مثال عددي: لصورة 512×512 ($N = 262144$): $\|C\|_F \approx 0.5895 \times 512 = 301.8$، في حين أن $\|C\|_2 \leq 1.45$.

النتيجة: $\|C\|_2 \leq 1.45$ لأي حجم صورة، بينما $\|C\|_F \approx 0.59\sqrt{N}$ يتضخّم معها.

الربط بالذكاء الاصطناعي: الالتفاف **مشغّل** مترجمٌ-الثبات (translation-equivariant)؛ ناظمه الطيفي يساوي أقصى استجابة تردّدية للنواة (قيمة ثابتة لا تتأثّر بحجم الصورة) — في حين أن الناظم الفروبنيوسي يقيس «مقداراً كلياً» يتضخّم بعدد البكسلات. أي تحليل ليبشيتز أو متانة لشبكة التفافية يجب أن يستخدم $\|C\|_2$؛ واستخدام $\|W\|_F$ في تنظيم الشبكات الالتفافية يعطي جزاءً يعتمد على دقة المدخل — وهو عيب معروف يفسّر الحاجة إلى إعادة ضبط المعامل عند تغيير دقة الصورة.

مثال (15-4.5): تراكم الخطأ عبر 24 طبقة — لماذا $\|W\|_2 \leq 1$ هو الأهم؟

المعطيات: $e_{l+1} = W_l e_l + \delta_l$ حيث $\|\delta_l\|_2 \leq \delta = 10^{-3}$ (خطأ تقريب/تكميم) و $\|W_l\|_2 = \gamma$ لكل l، و $L = 24$ طبقة، و $e_0 = 0$.

المطلوب: حدّ على $\|e_L\|_2$ كدالّة في γ، وقارن $\gamma = 1.2$ و $\gamma = 1.0$ و $\gamma = 0.9$.

الحل:

١. بالتوسيع المتكرّر: $e_L = \sum_{j=0}^{L-1} \left(\prod_{i=j+1}^{L-1} W_i\right) \delta_j$.

٢. بالتضاعف التحتي: $\|e_L\|_2 \leq \sum_{j=0}^{L-1} \gamma^{L-1-j}\, \delta = \delta \sum_{k=0}^{L-1} \gamma^k$.

٣. **الحالة** $\gamma = 1.2$: $\sum_{k=0}^{23} 1.2^k = \dfrac{1.2^{24} - 1}{0.2}$؛ و $1.2^{24} = e^{24 \times 0.182322} = e^{4.3757} = 79.50$ $\Longrightarrow$ المجموع $= \dfrac{78.50}{0.2} = 392.5$ $\Longrightarrow \|e_{24}\|_2 \leq 0.3925$.

٤. **الحالة** $\gamma = 1.0$: المجموع $= 24$ $\Longrightarrow \|e_{24}\|_2 \leq 0.024$.

٥. **الحالة** $\gamma = 0.9$: $\sum = \dfrac{1 - 0.9^{24}}{0.1} = \dfrac{1 - 0.0798}{0.1} = 9.202$ $\Longrightarrow \|e_{24}\|_2 \leq 0.0092$.

النتيجة: خطأ الإحداثي الواحد 10^{-3} يتضخّم إلى 0.3925 عند $\gamma = 1.2$ (معامل 392) مقابل 0.024 عند $\gamma = 1.0$ و 0.0092 عند $\gamma = 0.9$.

الربط بالذكاء الاصطناعي: هذه المتسلسلة الهندسية هي التحليل الكامل لتراكم الأخطاء في الشبكات العميقة — أخطاء التكميم (INT8/fb16)، وأخطاء الضغط، وأخطاء الحساب الموزّع. الاستنتاج العملي الحاسم: **إبقاء $\|W_l\|_2 \leq 1$ يحوّل التراكم من أُسّي إلى خطّي** ($L\delta$ بدلاً من $\gamma^L \delta$). وهذا بالضبط سبب شيوع التهيئة الوحدوية/المتعامدة (orthogonal initialization)، والتطبيع الطيفي، والقيود الصريحة $\|W\|_2 \leq 1$ في التدفّقات المقيَّدة (residual flows) والشبكات المتبقّية المقيَّدة.

4.4.5 أخطاء شائعة في النواظم المصفوفية

الخطأ الشائع	لماذا هو خطأ؟	التصحيح
استخدام $\|A\|_F$ بوصفه ثابت ليبشيتز	$\|I\|_2 = 1$ في حين أن $\|I\|_F = \sqrt{n}$	ثابت ليبشيتز هو $\|A\|_2$
افتراض التضاعف التحتي لناظم أقصى عنصر $\|A\|_{\max}$	مثال مضاد: $A = B = \mathbf{1}\mathbf{1}^\top$ (2×2) يعطي $\|AB\|_{\max} = 2 > 1$	استخدام نواظم مستحثة أو الفرونيوسي
استخدام $\rho(A) < 1$ شرطاً لـ «عدم الانفجار قصير المدى»	ρ يحكم السلوك **المقاربي** فقط؛ النمو العابر قد يكون ضخماً	افحص $\|A^k\|$ أيضاً (غيلفاند + النمو العابر)
ظنّ أن $\|A\|_2 = \rho(A)$	يصحّ للمصفوفات المتماثلة/الطبيعية فقط	للمصفوفات العامة: $\|A\|_2 = \sigma_1 \geq \rho(A)$
حساب $\|A\|_2$ بـ SVD في كل تكرار تدريب	تكلفة عالية؛ تكرار القوة بكفاءة كافية	استخدم تكرار القوة أو الحدود الرخيصة (23.5)
$\|A\|_\infty$ هو «أكبر مجموع **عمود**» و $\|A\|_1$ هو «أكبر مجموع **صف**»	التباس شائع جداً	تذكّر: $\|A\|_1$ يقترن بـ ℓ_1 ويجمع على الأعمدة
متسلسلة نيومان بشرط $\rho(A) < 1$ وحده لتقدير ناظم المعكوس	حدّ $\frac{1}{1-\|A\|}$ يتطلّب $\|A\| < 1$ بناظم **مستحث**	تحقّق من $\|A\| < 1$ لا من $\rho(A) < 1$
اعتبار رقم الحالة كبيراً «مجرد مسألة عددية»	هو خاصية **رياضية** للمسألة لا للخوارزمية	عالجه بالتنظيم/إعادة التصميم لا بدقة حسابية أعلى
اعتبار $\|A\|_\infty \leq \|A\|_2$	الاتجاه معكوس في العموم: قد يكون $\|A\|_\infty < \|A\|_2$ أو العكس	استخدم (23.5) للتحويل بينهما
$\|A\|_F$ لالتفاف مستقل عن حجم المدخل لكن ليس كذلك	يؤدي إلى معاملات تنظيم خاطئة عند تغيير الدقة	استخدم $\|C\|_2$ في التحليل واضبط التنظيم تبعاً لذلك

الفكرة في سطر: عائلة ℓ_p لم تتعامل مع المصفوفات بوصفها قوائم أرقام، بل بوصفها **مشغّلات** — بتطبيقها على **القيم المفردة** بدل الإحداثيات. فتولد عائلة **نواظم شاتن** $\|A\|_{S_p}$: S_1 = الناظم النووي (بديل الرتبة)، S_2 = الفرونيوسي، S_∞ = الطيفي. والمتراجحة الحاكمة التي تربط مصفوفتين هي **متراجحة فون نيومان**: الأثر الأعظم يحدث حين **تتطابق** محاور القيم المفردة.

1.5.5 الصياغة الرسمية

تعريف (نواظم شاتن — Schatten norms).

ليكن $A \in \mathbb{R}^{m\times n}$ بقيم مفردة $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ حيث $r = \operatorname{rank}(A)$. لأي $p \in [1,\infty]$:

$$\|A\|_{S_p} = \begin{cases} \left(\sum_{i=1}^{r} \sigma_i(A)^p\right)^{1/p}, & 1 \leq p < \infty \\ \sigma_1(A) = \|A\|_2, & p = \infty \end{cases} \tag{26.5}$$

والأعضاء الثلاثة الأهم:

$$\|A\|_{S_1} = \sum_i \sigma_i = \|A\|_* \text{ (النووي / trace norm)}, \qquad \|A\|_{S_2} = \sqrt{\textstyle\sum_i \sigma_i^2} = \|A\|_F, \qquad \|A\|_{S_\infty} = \sigma_1 = \|A\|_2$$

جدول رموز (26.5):

الرمز	المعنى	ملاحظات
p	أُسّ ناظم شاتن	$p \in [1,\infty]$
$\sigma_i(A)$	القيمة المفردة رقم i لـ A	مرتّبة تنازلياً، جذورُ القيم الذاتية لـ $A^\top A$
$r = \operatorname{rank}(A)$	رتبة المصفوفة = عدد القيم المفردة غير الصفرية	—
$\|A\|_{S_p}$	ناظم شاتن من الرتبة p	يُكتب أحياناً $\|A\|_p$ مع التمييز بالسياق
$\|A\|_{S_1} = \|A\|_*$	الناظم النووي (nuclear norm) / trace	**مجموع القيم المفردة؛ بديل مقعّب للرتبة**
$\|A\|_{S_2} = \|A\|_F$	الناظم الفرونيوسي	الحالة الوحيدة التي يتطابق فيها ناظم شاتن مع «ناظم القائمة»
$\|A\|_{S_\infty} = \|A\|_2$	الناظم الطيفي	أكبر قيمة مفردة
الرتابة في p	$1 \leq p \leq q \Rightarrow \|A\|_{S_p} \geq \|A\|_{S_q}$	معكوس رتابة ℓ_p ظاهرياً لأن العدد محدود بـ r
$\|A\|_{S_p}$ دالة على الطيف فقط	لا تعتمد على المتجهات المفردة	خاصية الثبات الوحدوي

نظرية (متراجحة فون نيومان للأثر — von Neumann).

لكل $A, B \in \mathbb{R}^{m\times n}$:

$$\left|\operatorname{tr}(A^\top B)\right| \;\le\; \sum_{i=1}^{\min(m,n)} \sigma_i(A)\,\sigma_i(B) \;=\; \big\langle \sigma(A),\, \sigma(B)\big\rangle \tag{27.5}$$

ويتحقّق التساوي (في القيمة المطلقة) إذا وفقط إذا كان لـ A و B **المتجهاتُ المفردة نفسها** (مع الترتيب والتوافق نفسه): أي $A = U\Sigma_A V^\top$ و $B = U\Sigma_B V^\top$ بالمصفوفتين الوحدويتين نفسيهما U, V.

جدول رموز (27.5):

الرمز	المعنى	ملاحظات
$\operatorname{tr}(\cdot)$	الأثر = مجموع القطر	الضرب الداخلي للمصفوفتين = $\operatorname{tr}(A^\top B) = \sum_{ij} A_{ij}B_{ij}$
$\|\operatorname{tr}(A^\top B)\|$	القيمة المطلقة للأثر	المقدار الذي نُقيّده
$\sigma_i(A), \sigma_i(B)$	القيم المفردة لكلتا المصفوفتين	**مرتّبتان تنازلياً** كلٌّ على حدة
$\sum_i \sigma_i(A)\sigma_i(B)$	الجداء التنازلي المتقابل	«أفضل ترتيب» — متراجحة إعادة الترتيب
$\langle \sigma(A), \sigma(B)\rangle$	الضرب الداخلي لشماعي القيم المفردة	الصيغة المختصرة
شرط التساوي	المحاور (المتجهات المفردة) متطابقة	U و V نفسيهما للمصفوفتين
U, V	المصفوفتان الوحدويتان في SVD	$U^\top U = I$، $V^\top V = I$
Σ_A, Σ_B	المصفوفتان القطريتان للقيم المفردة	عناصر قطرها σ_i
$\min(m,n)$	أصغر بُعدي المصفوفة = عدد القيم المفردة الممكنة	الحدّ الأعلى لعدد حدود الجداء

نظرية (هولدر لشاتن وازدواج النواظم المصفوفية).

ليكن p, q مترافقين ($\frac{1}{p}+\frac{1}{q}=1$). عندئذٍ:

$$\left|\operatorname{tr}(A^\top B)\right| \;\le\; \|A\|_2\,\|B\|_* \qquad \text{وخاصةً} \qquad \left|\operatorname{tr}(A^\top B)\right| \;\le\; \|A\|_{S_p}\,\|B\|_{S_q}, \tag{28.5}$$

والناظم الثنوي لناظم شاتن S_p هو S_q:

$$\big(\|\cdot\|_{S_p}\big)^* = \|\cdot\|_{S_q}, \qquad \|A\|_* \;=\; \max_{\|B\|_2\le 1} \operatorname{tr}(A^\top B), \qquad \|A\|_2 \;=\; \max_{\|B\|_*\le 1} \operatorname{tr}(A^\top B) \tag{29.5}$$

جدول رموز (28.5)–(29.5):

الرمز	المعنى	ملاحظات
p, q	أُسّان مترافقان	$1/p + 1/q = 1$
$\|A\|_{S_p}$	ناظم شاتن من الرتبة p لـ A	—
$\|B\|_{S_q}$	ناظم شاتن من الرتبة q لـ B	—
$\|A\|_2\|B\|_*$	الحالة $(p,q) = (\infty, 1)$	الأكثر استخداماً: طيفي × نووي
$\big(\|\cdot\|_{S_p}\big)^*$	الناظم الثنوي	يقابله S_q
$\max_{\|B\|_2\le 1} \operatorname{tr}(A^\top B)$	صيغة التعظيم للناظم النووي	يُحقّقها $B = UV^\top$ (مُجَمِّع الإشارات)
$\max_{\|B\|_*\le 1} \operatorname{tr}(A^\top B)$	صيغة التعظيم للناظم الطيفي	يُحقّقها $B = u_1 v_1^\top$
$UV^\top$	«مُجَمِّع الإشارات» (sign matrix) من SVD لـ A	$\operatorname{tr}(A^\top UV^\top) = \|A\|_*$ و $\|UV^\top\|_2 = 1$
$u_1 v_1^\top$	المكوّن المفرد الأول (رتبة 1)	σ_1 ويعطي $\|u_1 v_1^\top\|_* = 1$

نظرية (الثبات الوحدوي).

لكل مصفوفتين وحدويّتين $Q \in \mathbb{R}^{m\times m}$ و $R \in \mathbb{R}^{n\times n}$:

$$\|QAR^{\top}\|_{S_p} \;=\; \|A\|_{S_p} \quad \forall p \in [1,\infty]; \qquad \|A\|_{S_p} \text{ دالةٌ على القيم المفردة فقط} \tag{30.5}$$

نظرية (النووي بديلٌ مقعّب للرتبة، والرتبة الفعّالة).

على الكرة الطيفية $\{A : \|A\|_2 \le 1\}$، الناظم النووي هو **الغلاف المقعّب** (convex envelope) للرتبة. ويُقاس «التنائر الطيفي» بـ:

$$\|A\|_{*} \;\le\; \sqrt{r}\,\|A\|_F \quad\Longrightarrow\quad r \;\ge\; \frac{\|A\|_{*}^2}{\|A\|_F^2} \;=\; \operatorname{erank}(A) \tag{31.5}$$

جدول رموز (30.5)–(31.5):

الرمز	المعنى	ملاحظات
Q	مصفوفة وحدوية $m\times m$ $(Q^{\top}Q=I)$	تدوير في فضاء الخرج
R	مصفوفة وحدوية $n\times n$	تدوير في فضاء المدخل
$QAR^{\top}$	إعادةُ معلمة وحدوية للمصفوفة	لا تُغيّر أيّ ناظم شاتن
«الغلاف المقعّب»	أصغر دالة محدّبة تقلّ عن الدالة أو تساويها	يبرّر استخدام $\|\cdot\|_*$ بديلاً عن rank
$\{A : \|A\|_2 \le 1\}$	الكرة الطيفية	المجال الذي تُعرَّف عليه التغطية
$\operatorname{erank}(A)$	الرتبة الفعّالة (effective rank)	$= \|A\|_*^2/\|A\|_F^2 \in [1, r]$
$r \ge \operatorname{erank}$	الرتبة الفعّالة حدٌّ أدنى للرتبة	وهي مقياس مستمرّ (غير صحيح) للتعقيد الطيفي
$\sqrt{r}$	معامل التحويل النووي↔فرونيوسي	محكَم عند تساوي القيم المفردة

مبرّر الاستخدام: مسألة $\mathcal{A}(X) = b$ to subject min $\operatorname{rank}(X)$ (إكمال مصفوفة) هي صعبة-NP وغير محدّبة. الاسترخاء المقعّب الطبيعي هو $\mathcal{A}(X) = b$ to subject min $\|X\|_*$ — وهو برنامج محدّب قابل للحل. نظرية (31.5) والنتائج المرافقة (Candès–Recht، Candès–Tao) تضمن — تحت «عدم الترافق» (incoherence) وأخذ عيّنات كافية — أن الحلّين **يتطابقان**.

الشكل الهندسي: أفضل ترتيب للقيم المفردة هو التنازلي المتقابل؛ وأسوأ ترتيب هو المعكوس:

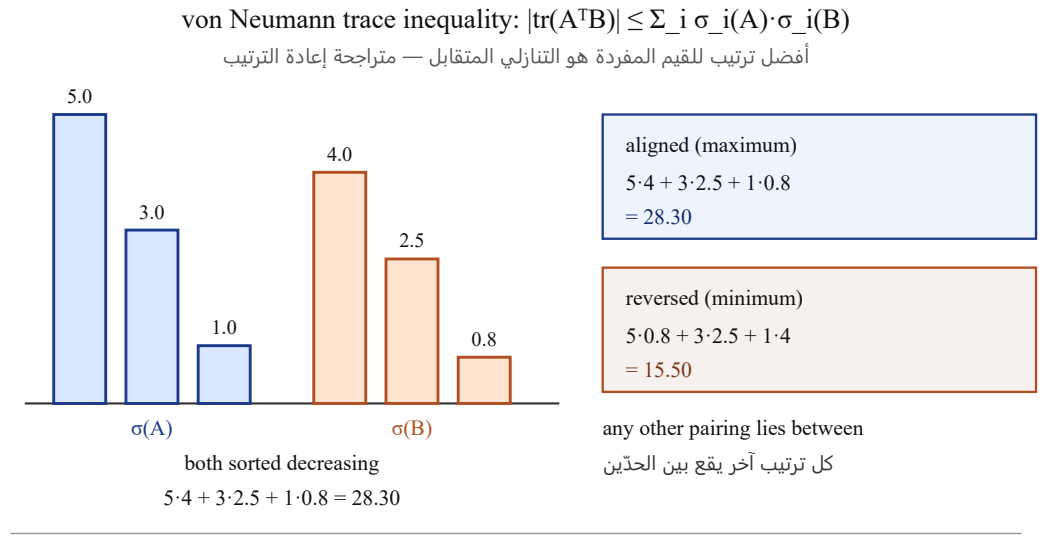
2.5.5 البرهان

برهان (27.5) — فون نيومان.

نكتب SVD: $A = U_A\Sigma_A V_A^{\top}$ و $B = U_B\Sigma_B V_B^{\top}$. بثبات الأثر تحت الدوران وبضرب الوحدويّات نردّ المسألة إلى:

$$\operatorname{tr}(A^{\top}B) = \operatorname{tr}\big(V_A\Sigma_A U_A^{\top}U_B\Sigma_B V_B^{\top}\big) = \operatorname{tr}\big(\Sigma_A Q \Sigma_B P^{\top}\big)$$

بوضع $Q = U_A^{\top}U_B$ و $P = V_A^{\top}V_B$ (وحدويّتان). نُثبت أولاً الحالة القطرية: ليكن $D_a = \operatorname{diag}(a_1 \ge \cdots \ge a_n \ge 0)$ و $D_b = \operatorname{diag}(b_1 \ge \cdots \ge b_n \ge 0)$، وليكن W وحدويّاً. عندئذٍ:



شكل ٥.٥: *
متراجحة فون نيومان للأثر وإعادة الترتيب

$$\operatorname{tr}(D_a W D_b W^\top) \;=\; \sum_{i,j} a_i b_j\, w_{ij}^2 \;=\; \sum_{i,j} a_i b_j\, m_{ij}$$

حيث $(w_{ij}^2) \;=\; M$ مصفوفة **مزدوجة العشوائية** (doubly stochastic): عناصرها غير سالبة ومجاميع صفوفها وأعمدتها $1 = (\text{لأن } WW^\top = W^\top W = I)$. مجال المصفوفات مزدوجة العشوائية هو **متعدّد أوجه بيركوف** الذي رؤوسه مصفوفات التباديل (نظرية بيركوف–فون نيومان). والدالة $M \;\mapsto\; \sum_{ij} a_i b_j m_{ij}$ خطّية، فتأخذ أعلاها على رأسٍ من الرؤوس، أي على مصفوفة تبديل Π:

$$\max_{W} \operatorname{tr}(D_a W D_b W^\top) \;=\; \max_{\Pi} \sum_i a_i\, b_{\pi(i)}$$

وبـ **متراجحة إعادة الترتيب** (rearrangement): أعظمُ قيمة لـ $\sum_i a_i b_{\pi(i)}$ مع a, b تنازليّين هي التبديل المطابق $\pi = \mathrm{id}$، أي $\sum_i a_i b_i$. إذن $|\operatorname{tr}(A^\top B)| \le \sum_i \sigma_i(A)\sigma_i(B)$. ■

برهان (28.5) — هولدر لشاتن.

من فون نيومان ثم هولدر العادي على شماعي القيم المفردة:

$$|\operatorname{tr}(A^\top B)| \;\le\; \sum_i \sigma_i(A)\sigma_i(B) \;\le\; \Big(\sum_i \sigma_i(A)^p\Big)^{1/p} \Big(\sum_i \sigma_i(B)^q\Big)^{1/q} \;=\; \|A\|_{S_p} \|B\|_{S_q}$$

وحالة $(p, q) = (\infty, 1)$ تعطي $|\operatorname{tr}(A^\top B)| \le \sigma_1(A) \sum_i \sigma_i(B) = \|A\|_2 \|B\|_*$. ■

برهان (29.5) — الازدواج.

من (28.5): $\operatorname{tr}(A^\top B) \le \|A\|_{S_p}\|B\|_{S_q}$ لكل B، فيكون الثنوي $\|A\|_{S_q} \le$. ولإثبات التساوي نختار B بمحاورَ مطابقةٍ لمحاور A: إن كان $A = U\Sigma_A V^\top$ نأخذ $B = U\Sigma_B V^\top$ بـ $\sigma_i(B) = \sigma_i(A)^{q-1}/\|A\|_{S_q}^{q-1}$؛ فـ $\|B\|_{S_p} = 1$ و $\operatorname{tr}(A^\top B) = \sum_i \sigma_i(A)\sigma_i(B) = \|A\|_{S_q}$ (تحقّق مباشر بـ $(q-1)p = q$). وحالة النووي: $B = UV^\top$ يعطي $\|B\|_2 = 1$ و $\operatorname{tr}(A^\top UV^\top) = \operatorname{tr}(V\Sigma_A U^\top UV^\top) = \operatorname{tr}(\Sigma_A) = \|A\|_*$. ✓ ■

برهان (30.5).

القيم المفردة لـ $QAR^\top$: بما أن Q, R وحدويّتان، فإن $(QAR^\top)^\top(QAR^\top) = RA^\top AR^\top$ — وهي مشابهة وحدوياً لـ $A^\top A$، فلهما القيم الذاتية نفسها، ومن ثم القيم المفردة نفسها. فكل ناظم شاتن (دالة على القيم المفردة فقط) ثابت. ■

برهان (31.5).

بكوشي–شفارتس على شماع القيم المفردة غير الصفرية (عددها r):

$$\|A\|_* = \sum_{i=1}^{r} \sigma_i \cdot 1 \;\le\; \sqrt{\sum_{i=1}^{r} \sigma_i^2}\,\sqrt{r} \;=\; \sqrt{r}\,\|A\|_F$$

وبالتربيع وإعادة الترتيب: $r \ge \|A\|_*^2/\|A\|_F^2$. وكون $\|\cdot\|_*$ هو الغلاف المقعّب لـ rank على الكرة الطيفية نتيجةٌ كلاسيكية (Fazel 2002؛ Recht–Fazel–Parrilo 2010) ونكتفي بالإحالة إليها. ■

3.5.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-5.5): حساب نواظم شاتن الأربعة لمصفوفة واحدة

المعطيات: مصفوفة A قيمها المفردة $\sigma(A) = (3.5,\ 2.1,\ 0.4)$.
المطلوب: احسب $\|A\|_{S_1}$ و $\|A\|_{S_2}$ و $\|A\|_{S_4}$ و $\|A\|_{S_\infty}$، وتحقّق من الرتابة في p.
الحل:

١. $\|A\|_{S_1} = \|A\|_* = 3.5 + 2.1 + 0.4 = 6.0$.

٢. $\|A\|_{S_2} = \|A\|_F = \sqrt{12.25 + 4.41 + 0.16} = \sqrt{16.82} = 4.1012$.

٣. $\|A\|_{S_4} = \left(3.5^4 + 2.1^4 + 0.4^4\right)^{1/4} = \left(150.0625 + 19.4481 + 0.0256\right)^{1/4} = (169.536)^{1/4} = 3.6084$.

٤. $\|A\|_{S_\infty} = \|A\|_2 = \sigma_1 = 3.5$.

٥. الرتابة: $3.5 \le 3.6084 \le 4.1012 \le 6.0$ ✓ — كلما كبر p صغر الناظم (عكس عائلة ℓ_p على المتجهات ظاهرياً).

النتيجة: $\|A\|_2 = 3.5$، $\|A\|_{S_4} = 3.6084$، $\|A\|_F = 4.1012$، $\|A\|_* = 6.0$.

الربط بالذكاء الاصطناعي: الناظم النووي يعاقب **مجموع** القيم المفردة فيدفع نحو الرتبة المنخفضة؛ والناظم الطيفي يعاقب **أكبرها** فقط فيدفع نحو «تسطيح» الطيف. اختيار p يحدّد أيّ نمط بنيوي تفضّله: $p = 1$ للرتبة المنخفضة، و $p = \infty$ للاستقرار/ليبشيتز، و $p = 2$ للطول الكلي (تنظيم decay weight المعتاد).

مثال (5.5-2): الناظم النووي بديلاً مقعّباً للرتبة في إكمال مصفوفة

المعطيات: مصفوفة تقييمات 4×4 ناقصة. اقترح المُحلّل إكمالين متوافقين مع المشاهَدات:

- X_1 بطيف مفرد $\sigma = (12,\ 3,\ 0.5,\ 0.2)$؛
- X_2 بطيف مفرد $\sigma = (6,\ 5,\ 4.8,\ 4.5)$.

المطلوب: أيّهما يختار مُصغِّر الناظم النووي؟ وما «الرتبة الفعّالة» لكل منهما؟

الحل:

١. $\|X_1\|_* = 12 + 3 + 0.5 + 0.2 = 15.7$.

٢. $\|X_2\|_* = 6 + 5 + 4.8 + 4.5 = 20.3$.

٣. إذن يُختار X_1 (ناظمه النووي أصغر).

٤. $\|X_1\|_F = \sqrt{144 + 9 + 0.25 + 0.04} = \sqrt{153.29} = 12.381$، $\operatorname{erank}(X_1) = \dfrac{15.7^2}{153.29} = \dfrac{246.49}{153.29} = 1.608$.

٥. $\|X_2\|_F = \sqrt{36 + 25 + 23.04 + 20.25} = \sqrt{104.29} = 10.212$، $\operatorname{erank}(X_2) = \dfrac{412.09}{104.29} = 3.951$.

٦. لاحظ أن $\|X_1\|_F > \|X_2\|_F$ — فلو استخدمنا تنظيماً فرونيوسياً لاخترنا X_2 (الأقلّ ناظماً فرونيوسياً) وهو **الأعلى رتبة فعّالة**.

النتيجة: مُصغِّر الناظم النووي يختار X_1 برتبة فعّالة 1.61، بينما التنظيم الفرونيوسي يختار X_2 برتبة فعّالة 3.95.

الربط بالذكاء الاصطناعي: هذا هو الفرق الحاسم في أنظمة التوصية (مصفوفة المستخدم–العنصر ناقصة بشدة): تصغير الرتبة يفترض أن التفضيلات محكومة بعدد قليل من العوامل الكامنة؛ والاسترخاء المقعّب $\|X\|_*$ هو البديل القابل للحل. أمّا التنظيم الفرونيوسي فلا «يرى» الرتبة إطلاقاً — فهو يقيس الطول الإجمالي لا توزيعه على الطيف.

مثال (5.5-3): تحقّق عددي من متراجحة فون نيومان بثلاثة ترتيبات

المعطيات: $A = \mathrm{diag}(4,\ 2.5,\ 1)$ وثلاثُ مصفوفات B بالقيم المفردة نفسها $\sigma(B) = (3,\ 2,\ 0.5)$ بترتيبات مختلفة: $B_1 = \mathrm{diag}(3,\ 2,\ 0.5)$ (مطابق)، و $B_2 = \mathrm{diag}(2,\ 3,\ 0.5)$ (مبدَّل جزئياً)، و $B_3 = \mathrm{diag}(0.5,\ 2,\ 3)$ (معكوس).

المطلوب: احسب $\mathrm{tr}(A^\top B_k)$ لكلٍّ منها وقارن بسقف فون نيومان.

الحل:

١. السقف: $\sum_i \sigma_i(A)\sigma_i(B) = 4 \times 3 + 2.5 \times 2 + 1 \times 0.5 = 12 + 5 + 0.5 = 17.5$.

٢. B_1 (مطابق): $\mathrm{tr}(A^\top B_1) = 4 \times 3 + 2.5 \times 2 + 1 \times 0.5 = 17.5$ — **يبلغ السقف** ✓ (شرط التساوي: المحاور متطابقة).

٣. B_2: $4 \times 2 + 2.5 \times 3 + 1 \times 0.5 = 8 + 7.5 + 0.5 = 16.0 \le 17.5$ ✓.

٤. B_3 (معكوس): $4 \times 0.5 + 2.5 \times 2 + 1 \times 3 = 2 + 5 + 3 = 10.0 \le 17.5$ ✓، وهو **الأدنى** (متراجحة إعادة الترتيب).

النتيجة: 17.5 (أقصى) $\ge 16.0 \ge 10.0$ (أدنى)، وكلها داخل سقف فون نيومان 17.5.

الربط بالذكاء الاصطناعي: القيمة $\mathrm{tr}(A^\top B)$ هي الضرب الداخلي بين مصفوفتين — وتظهر بوصفها «تشابهاً» في مقارنة الأوزان بين نموذجين (linear mode connectivity، دمج النماذج). متراجحة فون نيومان تقول: **التشابه الأقصى يتحقّق حين تتطابق المحاور المفردة، لا حين تتطابق القيم المفردة وحدها.** ولهذا تقيس بحوث دمج النماذج «محاذاةً» (alignment) قبل الجمع، لا مجرد تطابق الأطياف.

مثال (5.5-4): هندسة المحاذاة — من الأثر الأقصى إلى الأدنى بتدوير واحد

المعطيات: $A = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$ و $B = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}$. نُدوِّر B بزاوية $45°$: $B_\theta = QBQ^\top$ حيث $Q = \begin{pmatrix} c & -s \\ s & c \end{pmatrix}$ و $c = s = \frac{1}{\sqrt{2}}$.

المطلوب: احسب $\mathrm{tr}(A^\top B_\theta)$ وقارنه بالأقصى والأدنى الممكنين.

الحل:

١. الأقصى (محاور مطابقة): $\mathrm{tr}(A^\top B) = 3 \times 2 + 1 \times 0.5 = 6.5$.

٢. الأدنى (محاور معكوسة، أي B بترتيب $(0.5, 2)$): $\mathrm{tr} = 3 \times 0.5 + 1 \times 2 = 3.5$.

٣. الحساب: $B_\theta = \begin{pmatrix} 2c^2 + 0.5s^2 & 1.5cs \\ 1.5cs & 2s^2 + 0.5c^2 \end{pmatrix} = \begin{pmatrix} 1.25 & 0.75 \\ 0.75 & 1.25 \end{pmatrix}$.

٤. $\mathrm{tr}(A^\top B_\theta) = 3 \times 1.25 + 1 \times 1.25 = 3.75 + 1.25 = 5.0$.

٥. التحقّق: $3.5 \le 5.0 \le 6.5$ ✓.

٦. الثبات: $\|B_\theta\|_{S_p} = \|B\|_{S_p}$ لكل p (وحدويّة Q) — التدوير غيّر الأثر لا الناظم.

النتيجة: الأثر تراوح بين 3.5 و 6.5 حسب زاوية المحاور، بينما ناظم شاتن لم يتغيّر إطلاقاً.

الربط بالذكاء الاصطناعي: الرسالة: **الناظم يحمي «المقدار»، والمحاذاة تحدّد «التفاعل».** حين تُدمج تحديثات (مثل LoRA أو task vectors) فإن مقدار النتيجة يعتمد على زاوية المحاور المفردة بينها؛ وتجاهل ذلك يفسّر لماذا تبدو بعض عمليات الدمج «معجزة» وأخرى «كارثة» بالأوزان نفسها.

مثال (5-5.5): الناظم النووي لتحديث LoRA من رتبة r

المعطيات: تحديث منخفض الرتبة $\Delta W = u_1 v_1^\top + u_2 v_2^\top$ بمتجهات متعامدة: $\|u_1\|_2 = 1.8$، $\|v_1\|_2 = 2.2$، $\|u_2\|_2 = 1.1$، $\|v_2\|_2 = 1.5$.

المطلوب: قيم ΔW المفردة ونواظمه الثلاثة.

الحل:

١. كل حدّ $u_k v_k^\top$ رتبته 1 وقيمته المفردة الوحيدة $\|u_k\|_2 \|v_k\|_2$.

٢. بشرط التعامد ($u_1 \perp u_2$ و $v_1 \perp v_2$): طيف ΔW هو الاتحاد $= \{1.8 \times 2.2,\ 1.1 \times 1.5\} = \{3.96,\ 1.65\}$.

٣. $\|\Delta W\|_* = 3.96 + 1.65 = 5.61$.

٤. $\|\Delta W\|_F = \sqrt{15.6816 + 2.7225} = \sqrt{18.4041} = 4.2900$.

٥. $\|\Delta W\|_2 = 3.96$.

٦. التحقّق: $3.96 \le 4.2900 \le 5.61$ ✓.

النتيجة: $\sigma(\Delta W) = (3.96,\ 1.65)$، $\|\Delta W\|_* = 5.61$، $\|\Delta W\|_F = 4.290$، $\|\Delta W\|_2 = 3.96$.

الربط بالذكاء الاصطناعي: تحديث LoRA برتبة r له **على الأكثر** r قيمة مفردة غير صفرية — فالناظم النووي يصير مقياساً مباشراً لـ «مقدار التعديل» يُناسب الرتبة. ولأن $\|\Delta W\|_*$ هو البديل المقعّب للرتبة، فإن مراقبته أثناء الضبط الدقيق تكشف متى «يتضخّم» التحديث فعلياً مقابل متى يبقى محصوراً في اتجاهات قليلة — وهذا بالضبط ما يُراد من الضبط منخفض الرتبة.

مثال (6-5.5): الرتبة الفعّالة حدّاً أدنى للرتبة الحقيقية

المعطيات: مصفوفة A بـ $\|A\|_* = 12$ و $\|A\|_F = 4$.

المطلوب: حدّ أدنى لرتبة A، وبيان متى يُبلَغ هذا الحدّ.

الحل:

١. الصيغة (31.5): $r \ge \dfrac{\|A\|_*^2}{\|A\|_F^2} = \dfrac{144}{16} = 9$.

٢. إذن $\operatorname{rank}(A) \ge 9$.

٣. متى يُبلَغ الحدّ؟ الشرط اللازم للتساوي في كوشي–شفارتس المستخدمة في البرهان هو تساوي كل القيم المفردة غير الصفرية.

٤. لو كان $r = 9$ فعلاً لكانت كل القيم المفردة $1.\overline{3}$؛ $\frac{\|A\|_*}{9} = \frac{12}{9} = 1.\overline{3}$؛ والتحقّق: $\|A\|_F = \sqrt{9 \times (1.\overline{3})^2} = \sqrt{9 \times 1.7778} = \sqrt{16} = 4$ ✓.

٥. لو كان الطيف مركّزاً (مثلاً $\sigma = (3.9, 0.5, 0.5, \dots)$) لكانت الرتبة أكبر بكثير من 9 مع الناظمين أنفسهما تقريباً.

النتيجة: $r \geq 9$، والحدّ مُحكَم عند الطيف المسطّح.

الربط بالذكاء الاصطناعي: الرتبة الفعّالة $\text{erank} = \|A\|_*^2 / \|A\|_F^2$ مقياسٌ مستمرّ (غير صحيح) لـ «عدد الاتجاهات المهمّة فعلاً». وهي أداة تشخيص يومية: للجاكوبي، للتدرّجات، لمصفوفات التمثيل. قيمتها لا تحتاج إلا إلى الناظمين النووي والفرونيوسي، ولا تحتاج إلى حساب الرتبة نفسها (وهي كمية غير متصلة وحسّاسة للضجيج).

مثال (5.5-7): هولدر لشاتن $(p, q) = (\infty, 1)$ — متى يتفوّق على كوشي–شفارتس الفرونيوسي؟

المعطيات: تحديث أوزان منخفض الرتبة $\Delta W \in \mathbb{R}^{64 \times 64}$ بطيف مفرد $\sigma = (1.5, 1.0, 0.7)$ والباقي صفر؛ ومدخل X بـ $\|X\|_2 = 2.8$ و $\|X\|_F = 12$.

المطلوب: حدّان على التغيّر $\langle \Delta W, X \rangle = \text{tr}(\Delta W^\top X)$: أحدهما بهولدر لشاتن والآخر بكوشي–شفارتس الفرونيوسي.

الحل:

١. $\|\Delta W\|_* = 1.5 + 1.0 + 0.7 = 3.2$؛ و $\|\Delta W\|_F = \sqrt{2.25 + 1 + 0.49} = \sqrt{3.74} = 1.9339$.

٢. حدّ هولدر لشاتن $(p, q) = (\infty, 1)$: $|\langle \Delta W, X \rangle| \leq \|\Delta W\|_* \|X\|_2 = 3.2 \times 2.8 = 8.96$.

٣. حدّ كوشي–شفارتس الفرونيوسي: $|\langle \Delta W, X \rangle| \leq \|\Delta W\|_F \|X\|_F = 1.9339 \times 12 = 23.21$.

٤. المقارنة: $8.96 < 23.21$ — حدّ شاتن أحكم بـ 2.59 مرة.

النتيجة: $|\langle \Delta W, X \rangle| \leq 8.96$ بهولدر لشاتن، مقابل ≤ 23.21 بكوشي–شفارتس الفرونيوسي.

الربط بالذكاء الاصطناعي: القاعدة العامة: **إذا كان أحد الطرفين منخفض الرتبة، استخدم $(\infty, 1)$: نووي × طيفي.** السبب أن الناظم النووي «يلتقط» أن ΔW يؤثّر في ثلاثة اتجاهات فقط، في حين أن $\|X\|_F = 12$ يفترض أن كل الاتجاهات الـ 4096 نشطة. هذا الحدّ هو ما يُستخدم في تحليل استقرار الضبط الدقيق منخفض الرتبة وتحديثات المحوّلات.

مثال (5.5-8): قرار القطع في تقريب من رتبة منخفضة — كم مكوّناً نحتفظ به؟

المعطيات: مصفوفة أوزان A بطيف مفرد $\sigma = (8, 6, 5, 1, 0.9, 0.8, 0.7, 0.6)$.

المطلوب: احسب الرتبة الفعّالة، ثم خطأ القطع (الفرونيوسي النسبي) عند $k = 3$ و $k = 4$، وقرّر.

الحل:

١. $\|A\|_* = 8 + 6 + 5 + 1 + 0.9 + 0.8 + 0.7 + 0.6 = 23.0$.

٢. $\|A\|_F^2 = 64 + 36 + 25 + 1 + 0.81 + 0.64 + 0.49 + 0.36 = 128.30 \Rightarrow \|A\|_F = 11.327$.

٣. $\operatorname{erank}(A) = \dfrac{23.0^2}{128.30} = \dfrac{529}{128.30} = 4.123 \Rightarrow$ الرتبة الفعّالة ≈ 4 من أصل 8.

٤. القطع عند $k = 3$: خطأ فروبنيوسي $= \sqrt{1 + 0.81 + 0.64 + 0.49 + 0.36} = \sqrt{3.30} = 1.8166$؛ نسبياً $= \dfrac{1.8166}{11.327} = 16.0\%$.

٥. القطع عند $k = 4$: الخطأ $= \sqrt{0.81 + 0.64 + 0.49 + 0.36} = \sqrt{2.30} = 1.5166$؛ نسبياً 13.4%.

٦. القطع عند $k = 3$ حذف مكوّناً مقدارُه 1 (من 23) فكلّف 2.6 نقطة مئوية إضافية.

النتيجة: الرتبة الفعّالة 4.12 تشير إلى الاحتفاظ بـ 4 مكوّنات، والقطع عند 3 يكلّف 16% خطأً مقابل 13.4% عند 4.

الربط بالذكاء الاصطناعي: الرتبة الفعّالة هي «مؤشّر أوّلي» سريع لاختيار رتبة الضغط قبل حساب منحنى الخطأ الكامل: ابدأ من $k \approx \operatorname{erank}$ ثم اضبط بحسب ميزانية الدقة. وهي أيضاً مقياس «كم معلومة» تحتويها المصفوفة فعلاً — أدقّ بكثير من الرتبة الصحيحة التي تقفز من 8 إلى 8 بلا إنذار عن اقتراب المصفوفة من الرتبة المنخفضة.

مثال (5.5-9): الثبات الوحدوي — لماذا تنظيم فروبنيوسي مستقل عن إعادة المعلمة؟

المعطيات: $W = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}$، ونُدوّرها بزاوية $45°$: $W' = QWQ^\top$ بـ $Q = \begin{pmatrix} c & c \\ c & -c \end{pmatrix}$ و $c = \frac{1}{\sqrt{2}}$.

المطلوب: قارن النواظم الشاتنية والناظم الإحداثي ℓ_1 قبل التدوير وبعده.

الحل:

١. $W' = 2\,u_1 u_1^\top + 0.5\,u_2 u_2^\top$ حيث $u_1 = (c,\, c)$ و $u_2 = (c,\, -c)$:

$$W' = 2\begin{pmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{pmatrix} + 0.5\begin{pmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{pmatrix} = \begin{pmatrix} 1.25 & 0.75 \\ 0.75 & 1.25 \end{pmatrix}$$

٢. $\|W\|_F = \sqrt{4 + 0.25} = \sqrt{4.25} = 2.0616$؛ و $\|W'\|_F = \sqrt{1.5625 + 0.5625 + 0.5625 + 1.5625} = \sqrt{4.25} = 2.0616$ ✓ **متساويان.**

٣. $\|W\|_* = 2.5 = \|W'\|_*$ ✓، و $\|W\|_2 = 2 = \|W'\|_2$ ✓ (القيم المفردة نفسها $(2,\, 0.5)$).

٤. الناظم الإحداثي ℓ_1: $\|\operatorname{vec}(W)\|_1 = 2 + 0.5 = 2.5$؛ و $\|\operatorname{vec}(W')\|_1 = 1.25 + 0.75 + 0.75 + 1.25 = 4.0$ × **مختلفان** بمعامل 1.6.

النتيجة: نواظم شاتن (ومنها الفروبنيوسي) ثابتة تحت التدوير الوحدوي، أمّا التنظيم الإحداثي ℓ_1 فليس كذلك.

الربط بالذكاء الاصطناعي: لهذا يُقال إن تنظيم $\|W\|_F$ (weight decay) «غير متأثّر بإعادة المعلمة الوحدوية» — وهي خاصية مرغوبة تجعل الجزاء متسقاً مع هندسة المشغّل. أمّا التنظيم الإحداثي ℓ_1 (الذي يُستخدم للتناثر) فهو

يعتمد على المحاور: سيعاقب التمثيل نفسه بقيم مختلفة بعد أي تدوير. هذا يفسّر لماذا لا ينتج decay weight تناثراً بالمعنى الهندسي، بينما ينتجه تنظيم ℓ_1 الإحداثي (لكن بمحاور ثابتة يفرضها التمثيل).

مثال (5.5-10): فون نيومان مقابل كوشي–شفارتس الفرونيوسي على مصفوفتين متوازيتين

المعطيات: W_1 بطيف $\sigma = (5,\ 4,\ 3)$ و W_2 بطيف $\sigma = (4.5,\ 3.5,\ 2)$، ومحاورهما المفردة **متطابقة تماماً**.
المطلوب: احسب $\langle W_1, W_2 \rangle$ وقارن الحدّين.
الحل:

١. بالمحاذاة التامة: $\langle W_1, W_2 \rangle = \operatorname{tr}(W_1^\top W_2) = 5 \times 4.5 + 4 \times 3.5 + 3 \times 2 = 22.5 + 14 + 6 = 42.5$.

٢. حدّ فون نيومان: $\sum_i \sigma_i(W_1)\sigma_i(W_2) = 42.5$ — **مساوٍ تماماً** (لأن المحاور متطابقة) ✓.

٣. $\|W_1\|_F = \sqrt{25 + 16 + 9} = \sqrt{50} = 7.0711$؛ $\|W_2\|_F = \sqrt{20.25 + 12.25 + 4} = \sqrt{36.5} = 6.0415$.

٤. حدّ كوشي–شفارتس الفرونيوسي: $7.0711 \times 6.0415 = 42.72$.

٥. المقارنة: $42.5 \le 42.5 \le 42.72$ — فون نيومان **مُحكَم** هنا، وكوشي–شفارتس فضفاض بـ 0.22.

النتيجة: فون نيومان يعطي 42.5 (**مُحكَماً**) مقابل 42.72 لكوشي–شفارتس الفرونيوسي.
الربط بالذكاء الاصطناعي: متراجحة فون نيومان هي «كوشي–شفارتس الدقيقة» لفضاء المصفوفات: فهي تستثمر معرفة **المحاور** لا الأطوال وحدها. في تحليل «الترابط الخطي في الأوزان» (linear connectivity mode) بين نموذجين مضبوطين من أصل واحد، تكون المحاور شبه متطابقة، فتكون فون نيومان مُحكمة تقريباً — وهذا يمنح حدوداً أدقّ بكثير على مسافة الأوزان بين النموذجين.

مثال (5.5-11): تحقّق صريح من صيغة الثنوي $\|A\|_* = \max_{\|B\|_2 \le 1} \operatorname{tr}(A^\top B)$
المعطيات: $A = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ (متماثلة موجبة التحديد).
المطلوب: ابحث $B^\star$ بالشرط $\|B\|_2 \le 1$ التي تُعظّم $\operatorname{tr}(A^\top B)$، وتحقّق أن القيمة العظمى $= \|A\|_*$.
الحل:

١. تحليل A الطيفي: $A = Q\,\operatorname{diag}(4,2)Q^\top$ بـ $Q = \begin{pmatrix} c & c \\ c & -c \end{pmatrix}$ و $c = \frac{1}{\sqrt{2}}$ (تحقّق: $4\begin{pmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{pmatrix} + 2\begin{pmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{pmatrix} = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ ✓).

٢. القيم المفردة $(4, 2) \Rightarrow \|A\|_* = 6$ و $\|A\|_2 = 4$.

٣. المُعظِّم في (29.5) هو «مُجمِّع الإشارات» $B^\star = UV^\top$. وبما أن $A \succeq 0$ فإن $U = V = Q \Rightarrow B^\star = I$.

٤. التحقّق من الشرط: $\|B^\star\|_2 = \|I\|_2 = 1$ ✓.

٥. القيمة: $\|A\|_* = 6 = 3 + 3 = \operatorname{tr}(A) = \operatorname{tr}(A^\top I)$ ✓.

٦. تحقّق إضافي بـ $B = -I$: $\operatorname{tr}(A^\top(-I)) = -6$ (القيمة الدنيا)؛ وأي B آخر بـ $\|B\|_2 \le 1$ يعطي قيمةً في $[-6, 6]$.

النتيجة: $B^\star = I$ و $\|A\|_* = 6 = \max$ — صيغة الثنوي مؤكَّدة.

الربط بالذكاء الاصطناعي: صيغة الثنوي هذه هي التي تُنتج «شهادة المزدوج» (dual certfiicate) في مسائل إكمال المصفوفة وتقليل الرتبة: لإثبات أن A هو الحل الأمثل، يكفي إيجاد مصفوفة B بـ $\|B\|_2 \le 1$ تحقّق $\|A\|_* = \operatorname{tr}(A^\top B)$ (وشروطاً على المدى). هذه التقنية نفسها تظهر في تحليل الاسترخاء المحدّب لتدريب الشبكات (الجزء السابع).

مثال (5.5-12): دون جمعيّة الناظم النووي — متى تكون متساوية ومتى صارمة؟

المعطيات: حالتان على $\mathbb{R}^{2\times 2}$:

- (أ) $A = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}$ و $B = \begin{pmatrix} 0 & 0 \\ 0 & 3 \end{pmatrix}$ (دعمان متعامدان).
- (ب) $A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ و $B = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$ (دعمان متداخلان).

المطلوب: تحقّق من $\|A + B\|_* \le \|A\|_* + \|B\|_*$ وحدّد متى تكون المساواة.
الحل:

١. الحالة (أ): $\|A\|_* = 2$، $\|B\|_* = 3$، $A + B = \operatorname{diag}(2, 3) \Rightarrow \|A + B\|_* = 5 = 2 + 3$ — **مساواة.**

٢. الحالة (ب): $\|A\|_* = 2$، $\|B\|_* = 2$، $A + B = \operatorname{diag}(2, 0) \Rightarrow \|A + B\|_* = 2 < 4$ — **متراجحة صارمة.**

٣. القاعدة: المساواة تتحقّق عندما تكون «المساحات المفردة» (المدى ومدى المنقول) متعامدة — أي أن طيف المجموع هو **اتحاد** الطيفين.

٤. تطبيق على الكل: لو كانت A محصورة في الكتلة $(1:2,\ 1:2)$ و B في الكتلة $(3:4,\ 3:4)$ من مصفوفة 4×4 لكان $\|A + B\|_* = \|A\|_* + \|B\|_*$ تماماً.

النتيجة: $\|A + B\|_* \le \|A\|_* + \|B\|_*$؛ مساواةٌ عند تعامد الدعمين، وصارمةٌ عند التداخل.

الربط بالذكاء الاصطناعي: هذه الخاصية تفسّر سلوك «حساب المهام» (task arithmetic) عند دمج تحديثات LoRA محصورة في كتل مختلفة: الناظم النووي للنتيجة = مجموع النواظم، فلا «تداخل» يُفقد. أمّا إذا تداخلت الكتل فقد يكون المجموع أقصر بكثير من مجموع الأجزاء (تداخل هدّام) — وقياس الناظم النووي للنتيجة مقابل مجموع نواظم الأجزاء مؤشّر كمّي مباشر لمدى التداخل.

مثال (5.5-13): الناظم النووي لمصفوفة شبه موجبة = الأثر (بلا SVD!)

المعطيات: مصفوفة غرام/نواة $K \succeq 0$ قيمها الذاتية $(12,\ 5,\ 3,\ 1,\ 0.5)$.
المطلوب: احسب $\|K\|_*$ و $\|K\|_F$ والرتبة الفعّالة — دون حساب قيم مفردة.
الحل:

١. لأن $K \succeq 0$: كل القيم الذاتية غير سالبة، والقيم المفردة = القيم الذاتية $\Longrightarrow \|K\|_* = \sum_i \lambda_i = \operatorname{tr}(K)$.

٢. $\|K\|_* = 12 + 5 + 3 + 1 + 0.5 = 21.5$.

٣. $\|K\|_F = \sqrt{144 + 25 + 9 + 1 + 0.25} = \sqrt{179.25} = 13.385$.

٤. $\operatorname{erank}(K) = \dfrac{21.5^2}{179.25} = \dfrac{462.25}{179.25} = 2.579$.

٥. $\|K\|_2 = \lambda_{\max} = 12$.

النتيجة: $\|K\|_* = \operatorname{tr}(K) = 21.5$، $\|K\|_F = 13.385$، والرتبة الفعّالة 2.58 من أصل 5.
الربط بالذكاء الاصطناعي: «النووي = الأثر» للمصفوفات شبه الموجبة يجعل النووي **رخيصاً جداً** في حالات مهمّة: مصفوفات الغرام، مصفوفات النواة، مصفوفات التغاير، ومصفوفات فيشر للمعلومات. في كل هذه الحالات يصير قياس الرتبة الفعّالة مجرد نسبة بين الأثر ومجموع مربّعات القيم الذاتية — بلا SVD. ويُستخدم ذلك في مراقبة «مدى استغلال» فضاء التمثيل في الشبكات.

مثال (5.5-14): الرتبة الفعّالة للتدرّج — تشخيص توقّف المُحسِّن

المعطيات: طيف تدرّج G في بداية التدريب: $\sigma = (10,\ 8,\ 7,\ 6,\ 5,\ 4,\ 3,\ 2)$. وفي مرحلة لاحقة: $\sigma = (18,\ 3,\ 2,\ 1.5,\ 1,\ 0.8,\ 0.6,\ 0.4)$.
المطلوب: احسب $\|G\|_F$ والرتبة الفعّالة في الحالتين وفسّر.
الحل:

١. الحالة الأولى: $\|G\|_* = 45$؛ $\|G\|_F^2 = 100 + 64 + 49 + 36 + 25 + 16 + 9 + 4 = 303 \Longrightarrow$ $\|G\|_F = 17.407$؛ $\operatorname{erank} = \dfrac{2025}{303} = 6.683$.

٢. الحالة الثانية: $\|G\|_* = 18 + 3 + 2 + 1.5 + 1 + 0.8 + 0.6 + 0.4 = 27.3$؛ $\|G\|_F^2 = 324 + 9 + 4 + 2.25 + 1 + 0.64 + 0.36 + 0.16 = 341.41 \Longrightarrow \|G\|_F = 18.477$؛ $\operatorname{erank} = \dfrac{745.29}{341.41} = 2.183$.

٣. المقارنة: $\|G\|_F$ **ازداد** قليلاً ($17.41 \rightarrow 18.48$، أي $+6\%$)؛ لكن الرتبة الفعّالة **انهارت** من 6.68 إلى 2.18 (-67%).

النتيجة: التدرّج صار «أثقل» قليلاً لكنه محصور في اتجاهين اثنين بدل سبعة.
الربط بالذكاء الاصطناعي: هذا نمط فشل كلاسيكي: الناظم الكلي للتدرّج لا يتغيّر كثيراً فيبدو التدريب «حيّاً»، لكن التحديثات كلها تتجمّع في اتجاهين فقط فتتوقّف القدرة على استكشاف بقيّة الفضاء. وهو أيضاً سبب نجاح طرق

الضغط المتناثر والتكميم في التدريب الموزّع: التدرّج **فعلياً** منخفض الرتبة وإن لم يكن كذلك صراحةً. مؤشّر الرتبة الفعّالة يكشف ذلك بجُهد حسابي لا يُذكر مقابل SVD كاملة.

مثال (5.5-15): كشف انهيار التمثيل في التعلّم المتناقض بالرتبة الفعّالة

المعطيات: مصفوفة تغاير تمثيلات $C \in \mathbb{R}^{8\times 8}$ (شبه موجبة). قبل الانهيار: قيم ذاتية $(8,\ 6,\ 5,\ 4,\ 3,\ 2,\ 1.5,\ 1)$. بعد الانهيار: $(20,\ 4,\ 2,\ 1,\ 0.6,\ 0.4,\ 0.3,\ 0.2)$.

المطلوب: احسب $\|C\|_F$ والرتبة الفعّالة في الحالتين، وبيّن لماذا لا يكفي الناظم الفرونيوسي للكشف.

الحل:

١. قبل: $\|C\|_* = \operatorname{tr}(C) = 30.5$؛ $\|C\|_F^2 = 64+36+25+16+9+4+2.25+1 = 157.25 \Longrightarrow$ $\|C\|_F = 12.540$؛ $\operatorname{erank} = \dfrac{930.25}{157.25} = 5.916$.

٢. بعد: $\|C\|_* = 20+4+2+1+0.6+0.4+0.3+0.2 = 28.5$؛ $\|C\|_F^2 = 400+16+4+1+0.36+0.16+0.09+0.04 = 421.69 \Longrightarrow \|C\|_F = 20.535$؛ $\operatorname{erank} = \dfrac{812.25}{421.69} = 1.926$.

٣. المقارنة: $\|C\|_F$ **نما** من 12.54 إلى 20.54 (+64%)، في حين أن الرتبة الفعّالة **انهارت** من 5.92 إلى 1.93 (−67%).

النتيجة: مؤشّر الفرونيوسي يوحي «بنمو التمثيل» بينما الواقع أنه انهار على اتجاهين.

الربط بالذكاء الاصطناعي: هذا هو المبرّر الرياضي لِما تفعله VICReg و Barlow Twins: فهي تُضيف جزاءً على **التغاير** (يمنع تركّز الطيف) لا جزاءً على الناظم الكلي. الناظم الفرونيوسي يعاقب «الصغر» ولا يعاقب «التركّز»، أمّا الرتبة الفعّالة — وهي نسبة النووي إلى الفرونيوسي — فتقيس التركّز مباشرة. القاعدة التشخيصية: **راقب** erank **لا** $\|C\|_F$.

4.5.5 أخطاء شائعة في نواظم شاتن ومتراجحة فون نيومان

الخطأ الشائع	لماذا هو خطأ؟	التصحيح
الخلط بين $\|A\|_*$ (نووي) و $\|A\|_2$ (طيفي)	الأول مجموع القيم المفردة والثاني أكبرها	اكتب الرمز كاملاً ولا تكتفِ بالنجمة
افتراض $\|A\|_{S_p}$ يتناقص مع p كعائلة ℓ_p	الرتابة معكوسة ظاهرياً: $S_1 \geq S_2 \geq S_\infty$	تذكّر: S_∞ = أكبر قيمة مفردة = الأصغر
استخدام $\|A\|_F$ لقياس «الرتبة» أو التناثر الطيفي	فرونيوسي أعمى عن توزيع الطيف	استخدم النووي أو الرتبة الفعّالة
ظنّ أن فون نيومان تتطلّب تطابق القيم المفردة	التساوي يتطلّب تطابق **المحاور** (المتجهات المفردة)	افحص U, V لا Σ وحدها
تطبيق $\lvert\operatorname{tr}(A^\top B)\rvert \leq \|A\|_F\|B\|_F$ دائماً	صحيح لكنه قد يكون فضفاضاً بمعامل كبير عند انخفاض الرتبة	استخدم $\|A\|_2\|B\|_*$: لأحد الطرفين منخفض الرتبة
حساب $\|A\|_*$ بـ SVD لمصفوفة شبه موجبة	لا حاجة: $\|A\|_* = \operatorname{tr}(A)$ إذا كان $A \succeq 0$	تحقّق من شبه الموجبية أولاً
اعتبار $\|A\|_* \leq \|A\|_F$	الاتجاه معكوس: $\|A\|_* \geq \|A\|_F \geq \|A\|_2$	الصيغة الصحيحة: $\|A\|_* \leq \sqrt{r}\|A\|_F$
تجاهل أن الناظم النووي **غير قابل للاشتقاق** عند تكرار القيم المفردة	يسبّب مشكلات في خوارزميات التدرّج	استخدم دون التدرّج (subgradient) أو تنعيماً
س دون الجمعيّة $\|A+B\|_* \leq \|A\|_* + \|B\|_*$ مساواةً دائماً	صارمة عند تداخل الدعمين	تحقّق من تعامد المدى/مدى المنقول
الخلط بين «الرتبة» و«الرتبة الفعّالة»	الأولى صحيحة وغير متصلة؛ الثانية مستمرّة وحدٌّ أدنى	استخدم erank للتشخيص، والرتبة للقرارات البنيوية

الفكرة في سطر: في الأبعاد العالية، النواظم **لا تتقلّب**: طولُ متجه عشوائي، وناظمُ مصفوفة عشوائية، وطولُ إسقاطٍ عشوائي — كلّها تتركّز حول قيمتها المتوقَّعة بتركيزٍ أُسّي. هذه الظاهرة هي التي تجعل «البعد العالي» مكاناً صالحاً للعمل: المسافات محفوظة، والأخطاء العشوائية قابلة للضبط، والحدودُ الأسوأ-حالة (التي رأيناها في 3.5) متشائمة بمقدار جذري.

1.6.5 الصياغة الرسمية

نظرية (لمّة جونسون-ليندنشتراوس — JL).

ليكن $X \subseteq \mathbb{R}^d$ مجموعةً من n نقطة، وليكن $\varepsilon \in (0,1)$ و $\delta \in (0,1)$. لتكن $R \in \mathbb{R}^{k \times d}$ مصفوفة إسقاط عشوائي بمدخلات مستقلّة $R_{ij} \sim \mathcal{N}(0,\, 1/k)$. إذا كان

$$k \;\geq\; \frac{4\,\ln\!\left(n^2/\delta\right)}{\varepsilon^2 - \varepsilon^3} \qquad \Big(\text{وبصيغة مقاربة: } k = \mathcal{O}\!\left(\varepsilon^{-2}\log n\right)\Big) \tag{33.5}$$

فإنه باحتمال $\geq 1-\delta$ يتحقّق **لجميع الأزواج في وقت واحد**:

$$(1-\varepsilon)\,\|x-y\|_2^2 \;\leq\; \|Rx - Ry\|_2^2 \;\leq\; (1+\varepsilon)\,\|x-y\|_2^2, \qquad \forall\, x, y \in X$$

جدول رموز (33.5):

الرمز	المعنى	ملاحظات
X	مجموعة النقاط المراد إسقاطها	قد تكون تضمينات، أو عيّنات تدريب
$n = \lvert X\rvert$	عدد النقاط	عدد الأزواج $\binom{n}{2} \leq n^2/2$
d	البعد الأصلي	البعد المُراد تخفيضه
k	البعد بعد الإسقاط	الهدف: $k \ll d$
ε	التشويه المسموح (نسبةً إلى مربّع المسافة)	$\varepsilon = 0.1$ يعني $\pm 10\%$ في المربّع، أي $\approx \pm 5\%$ في المسافة
δ	احتمال الفشل المسموح	$\delta = 0.01$ يعني نجاحاً بـ 99%
R	مصفوفة الإسقاط العشوائي $k \times d$	X لا تعتمد على (oblivious): «عمياء»
$R_{ij} \sim \mathcal{N}(0, 1/k)$	توزيع المدخلات	التباين $1/k$ يجعل $\mathbb{E}\|Rx\|^2 = \|x\|^2$
$\ln$	اللوغاريتم الطبيعي	—
n^2 في اللوغاريتم	يأتي من اتحاد الاحتمالات على كل الأزواج	$\binom{n}{2} \leq n^2/2$
$(1 \pm \varepsilon)$ على **المربّع**	JL تحفظ **مربّعات** المسافات	للمسافات نفسها: $\sqrt{1 \pm \varepsilon}$
$\mathcal{O}(\varepsilon^{-2}\log n)$	الصيغة المقاربة الشهيرة	البعد المطلوب **لا يعتمد على** d **إطلاقاً**

نظرية (تركيز متجه واحد — χ^2).

لكل متجه ثابت $x \neq 0$:

$$\frac{k\,\|Rx\|_2^2}{\|x\|_2^2} \;\sim\; \chi^2_k, \qquad \mathbb{E}\|Rx\|_2^2 = \|x\|_2^2, \qquad \mathbb{P}\Big(\big|\,\|Rx\|_2^2 - \|x\|_2^2\,\big| \geq \varepsilon \|x\|_2^2\Big) \;\leq\; 2\exp\!\Big(-\tfrac{k(\varepsilon^2-\varepsilon^3)}{4}\Big) \tag{34.5}$$

جدول رموز (34.5):

الرمز	المعنى	ملاحظات
χ^2_k	توزيع مربع كاي بـ k درجة حرية	مجموع مربّعات k متغيّر قياسي
$\mathbb{E}\|Rx\|^2 = \|x\|^2$	الإسقاط **غير متحيّز** للطول	بفضل التباين $1/k$
$k\|Rx\|^2/\|x\|^2 \sim \chi^2_k$	التوزيع الدقيق	نسبة التركيز تحكمها χ^2
$2\exp(\cdot)$	الحدّ ذو الطرفين (أعلى وأسفل)	اتحاد احتمالَي الذيلين
$\varepsilon^2 - \varepsilon^3$	دالة التشويه في الأُسّ	أعظمُ قيمة لها على $(0,1)$ هي $\frac{4}{27}$ عند $\varepsilon = \frac{2}{3}$
$-k(\cdot)/4$	معدّل الاضمحلال الأُسّي	يتناسب مع k طرداً
الملاحظة الحاسمة	التركيز يعتمد على k **فقط**، لا على d	هذا هو سرّ قوّة JL

نظرية (تركيز ناظم المتجه الغاوسي).

ليكن $g \sim \mathcal{N}(0, I_d)$. الدالة $g \mapsto \|g\|_2$ هي 1-ليبشيتز، فبتركيز الغاوسي:

$$\mathbb{E}\|g\|_2^2 = d, \qquad \mathbb{E}\|g\|_2 \le \sqrt{d}, \qquad \mathbb{P}\Big(\big|\|g\|_2 - \mathbb{E}\|g\|_2\big| \ge t\Big) \;\le\; 2\,e^{-t^2/2} \tag{35.5}$$

جدول رموز (35.5):

الرمز	المعنى	ملاحظات
$g \sim \mathcal{N}(0, I_d)$	متجه غاوسي قياسي في $\mathbb{R}^d$	كل إحداثي $\mathcal{N}(0,1)$ مستقل
$\mathbb{E}\|g\|_2^2 = d$	مجموع التباينات	دقيق
$\mathbb{E}\|g\|_2 \le \sqrt{d}$	يتبع من Jensen (تربيع مقعّر)	والقيمة الفعلية $\sqrt{d}\,(1+\mathcal{O}(1/d))$
$\big\|\|g\| - \|h\|\big\| \le \|g-h\|_2$	1-ليبشيتز	من المتراجحة الفرقية
$2e^{-t^2/2}$	ذيل غاوسي	اضمحلال أُسّي في t^2
t	الانحراف المسموح	بالوحدات المطلقة (لا النسبية)
الانحراف النسبي	$\approx t/\sqrt{d}$	يتناقص مع البعد — «لعنة» تصبح «نعمة»

نظرية (ناظم المصفوفة العشوائية — غوردون / باي-ين).

ليكن $W \in \mathbb{R}^{m\times n}$ بمدخلات مستقلّة $\mathcal{N}(0, \sigma^2)$. عندئذٍ:

$$\mathbb{E}\|W\|_2 \;\le\; \sigma\big(\sqrt{m} + \sqrt{n}\big), \qquad \mathbb{P}\Big(\|W\|_2 \ge \mathbb{E}\|W\|_2 + t\Big) \;\le\; e^{-t^2/(2\sigma^2)}, \qquad \|W\|_F \approx \sigma\sqrt{mn} \tag{36.5}$$

جدول رموز (36.5):

الرمز	المعنى	ملاحظات
W	مصفوفة عشوائية $m \times n$	تهيئة أوزان، مصفوفة قياس عشوائية
σ^2	تباين المدخلات	في التهيئة: $\sigma^2 = 1/\text{fan_in}$ أو $2/\text{fan_in}$
$\sqrt{m} + \sqrt{n}$	النموذج النموذجي للناظم الطيفي	قانون غوردون
$\mathbb{E}\|W\|_2 \le \sigma(\sqrt{m}+\sqrt{n})$	الحدّ من فوق	محكَم مقارباً (باي-ين)
$e^{-t^2/(2\sigma^2)}$	تركيز أُسّي	لأن $\|W\|_2$ دالة σ-ليبشيتز في المدخلات
$\sqrt{mn}$	الناظم الفروبنيوسي النموذجي	أكبر من الطيفي بمعامل $\approx \frac{\sqrt{mn}}{\sqrt{m}+\sqrt{n}}$
$\frac{\sqrt{mn}}{\sqrt{m}+\sqrt{n}}$	معامل الفجوة	لمصفوفة مربّعة $n \times n$: $\frac{\sqrt{n}}{2}$ — ينمو مع العرض!

نتيجة (حفظ الضروب الداخلية). من JL بالاستقطاب (polarization):

$$\big|\langle Rx,\, Ry\rangle - \langle x,\, y\rangle\big| \;\le\; \frac{\varepsilon}{2}\big(\|x\|_2^2 + \|y\|_2^2\big) \;\xrightarrow[\|x\|=\|y\|=1]{}\; \le \varepsilon \tag{37.5}$$

نتيجة (تضمين الفضاءات الجزئية — subspace embedding). لإسقاط يحفظ **كل** المتجهات في فضاء جزئي بُعده d_0 (لا n نقطة منفصلة):

$$k \;=\; \mathcal{O}\!\left(\frac{d_0 + \ln(1/\delta)}{\varepsilon^2}\right) \quad\Longrightarrow\quad (1-\varepsilon)\|x\|^2 \le \|Rx\|^2 \le (1+\varepsilon)\|x\|^2,\ \forall x \in \mathcal{S} \tag{38.5}$$

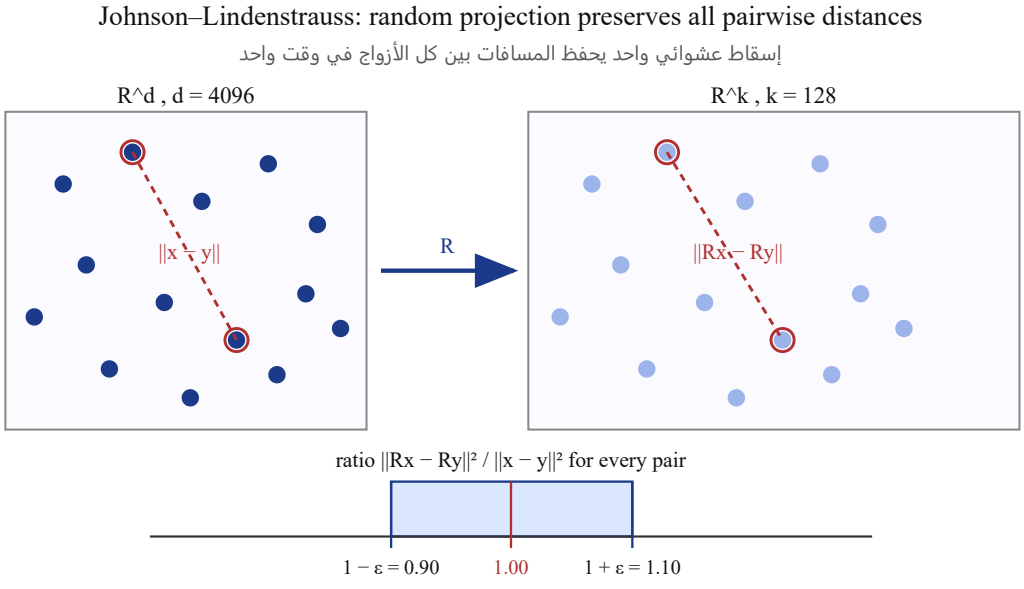
نتيجة (إحكام لمّة JL — الحدّ الأدنى). البعد $k = \mathcal{O}(\varepsilon^{-2}\log n)$ **مثاليّ** من حيث الاعتماد على ε و n:

$$k \;=\; \Omega\!\left(\varepsilon^{-2}\log n\right) \quad \text{ضروري} \tag{39.5}$$

جدول رموز (37.5)–(39.5):

الرمز	المعنى	ملاحظات
$\langle Rx, Ry\rangle$	الضرب الداخلي بعد الإسقاط	يحسب التشابه
$\langle x, y\rangle$	الضرب الداخلي الأصلي	—
$\frac{\varepsilon}{2}(\|x\|^2+\|y\|^2)$	حدّ الخطأ العام	—
$\leq \varepsilon$ للمتجهات الوحدية	الحالة الشائعة في التضمينات المُطبَّعة	يبرّر البحث بالجداء الداخلي بعد الإسقاط
«الاستقطاب»	$\langle u, v\rangle = \frac{1}{4}(\|u+v\|^2 - \|u-v\|^2)$	المتطابقة التي تنقل JL من المسافات إلى الضروب
d_0	بُعد الفضاء الجزئي $\mathcal{S}$	أصغر بكثير من d في التطبيقات
$\mathcal{S}$	فضاء جزئي (subspace)	مثلاً فضاء الأعمدة الـ d_0 الأولى
(38.5) مقابل (33.5)	الأول يحفظ **مجموعةً غير منتهية**؛ والثاني n نقطة	(38.5) أقوى وأعمّ
$\Omega(\cdot)$	حدّ أدنى مقاربي	يعني «لا يمكن تحسين الاعتماد على ε, n»
النتيجة	البعد المطلوب $\asymp \varepsilon^{-2}\log n$	الاعتماد على d معدوم، والاعتماد على n لوغاريتمي

الشكل الهندسي: إسقاط عشوائي واحد يحفظ **كل** المسافات دفعةً واحدة:



شكل ٦.٥: *
لمّة جونسون–ليندنشتراوس: إسقاط عشوائي يحفظ المسافات

2.6.5 البرهان

برهان (34.5).

ليكن $x \neq 0$ ثابتاً. كل إحداثي من Rx هو $(Rx)_j = \sum_i R_{ji}x_i$ — تركيبة خطية لمتغيّرات غاوسية مستقلّة، فهو غاوسي بتباين $\sum_i \mathrm{Var}(R_{ji})x_i^2 = \frac{1}{k}\|x\|_2^2$. إذن:

$$\|Rx\|_2^2 \;=\; \frac{\|x\|_2^2}{k}\sum_{j=1}^{k} Z_j^2, \qquad Z_j \sim \mathcal{N}(0,1) \text{ مستقلّة}$$

أي أن $Y = \dfrac{k\|Rx\|^2}{\|x\|^2} \sim \chi^2_k$، و $\mathbb{E}\|Rx\|^2 = \frac{\|x\|^2}{k}\cdot k = \|x\|^2$ ✓. أما الذيول فبـ شيرنوف: لكل $0 < \varepsilon < 1$،

$$\mathbb{P}\big(Y \ge (1+\varepsilon)k\big) \le \big((1+\varepsilon)e^{-\varepsilon}\big)^{k/2} = \exp\Big(-\tfrac{k}{2}\big(\varepsilon - \ln(1+\varepsilon)\big)\Big) \;\le\; \exp\Big(-\tfrac{k}{2}\big(\tfrac{\varepsilon^2}{2} - \tfrac{\varepsilon^3}{3}\big)\Big)$$

حيث استخدمنا $\ln(1+\varepsilon) \le \varepsilon - \frac{\varepsilon^2}{2} + \frac{\varepsilon^3}{3}$. وبالمثل للذيل الأسفل $\mathbb{P}(Y \le (1-\varepsilon)k) \le \exp\big(-\frac{k\varepsilon^2}{4}\big)$. وباتحاد الاحتمالين والحطّ إلى الصيغة المتحفّظة $\frac{\varepsilon^2-\varepsilon^3}{4}$ نحصل على (34.5). ■

برهان (33.5).

نُطبّق (34.5) على متجه الفرق $z = x - y$ — وهو متجه ثابت لا يعتمد على R (لأن R عمياء). عدد الأزواج $\binom{n}{2} \le n^2/2$. باتحاد الاحتمالات:

$$\mathbb{P}(\text{فشل أيّ زوج}) \;\le\; \frac{n^2}{2}\cdot 2\exp\Big(-\tfrac{k(\varepsilon^2-\varepsilon^3)}{4}\Big) = n^2\exp\Big(-\tfrac{k(\varepsilon^2-\varepsilon^3)}{4}\Big)$$

وبجعل هذا $\le \delta$ نحصل على $k \ge \dfrac{4\ln(n^2/\delta)}{\varepsilon^2-\varepsilon^3}$. ■

برهان (35.5).

الدالة $f(g) = \|g\|_2$ تحقّق $|f(g)-f(h)| \le \|g-h\|_2$ (المتراجحة الفرقية)، فهي 1-ليبشيتز. وبتركيز قياس الغاوس (Gaussian functions): Lipschitz for concentration $\mathbb{P}(|f(g)-\mathbb{E}f| \ge t) \le 2e^{-t^2/2}$. أمّا $\mathbb{E}\|g\|^2 = \sum_i \mathbb{E}g_i^2 = d$، و $\mathbb{E}\|g\| \le \sqrt{\mathbb{E}\|g\|^2} = \sqrt{d}$ بتطبيق Jensen على الدالة المقعّرة $\sqrt{\cdot}$. ■

برهان (36.5).

نكتب $W = \sigma G$ بـ G ذي مدخلات $\mathcal{N}(0,1)$. الدالة $G \mapsto \|G\|_2$ هي 1-ليبشيتز بالناظم الفرونيوسي على $\mathbb{R}^{m\times n}$ (لأن $\big|\|G\|_2 - \|H\|_2\big| \le \|G-H\|_2 \le \|G-H\|_F$)؛ فبتركيز الغاوس في بُعد mn: $\mathbb{P}(\|G\|_2 \ge \mathbb{E}\|G\|_2 + s) \le e^{-s^2/2}$. وبالتحجيم $t = \sigma s$ نحصل على الحدّ الثاني. أمّا الحدّ الأول $\mathbb{E}\|W\|_2 \le \sigma(\sqrt{m}+\sqrt{n})$ فهو **لامتساوية غوردون** (Gordon) للعمليات الغاوسية، ونكتفي بالإحالة إليها؛ ونظرية باي-ين (Bai–Yin) تكملها بأن النسبة $\to 1$ مقاربياً. ■

برهان (37.5).

بالاستقطاب:

$$\langle Rx, Ry\rangle - \langle x, y\rangle = \tfrac{1}{4}\Big[\big(\|R(x+y)\|^2 - \|x+y\|^2\big) - \big(\|R(x-y)\|^2 - \|x-y\|^2\big)\Big]$$

وبتطبيق JL على المتجهين $x+y$ و $x-y$ ثم متراجحة المثلث:

$$\big|\langle Rx,Ry\rangle-\langle x,y\rangle\big| \le \tfrac{1}{4}\Big[\varepsilon\|x+y\|^2+\varepsilon\|x-y\|^2\Big] = \tfrac{\varepsilon}{4}\big(2\|x\|^2+2\|y\|^2\big) = \tfrac{\varepsilon}{2}\big(\|x\|^2+\|y\|^2\big) \qquad \blacksquare$$

تنبيه تفسيري: JL تحفظ **مربّعات** المسافات ضمن $(1\pm\varepsilon)$؛ فالمسافات نفسها محفوظة ضمن $\sqrt{1+\varepsilon} \le 1+\tfrac{\varepsilon}{2}$ و $\sqrt{1-\varepsilon} \ge 1-\tfrac{\varepsilon}{2}$ — أي ضمن $(1\pm\tfrac{\varepsilon}{2})$ تقريباً. كثير من الأخطاء في الأدبيات التطبيقية يأتي من الخلط بين النسبتين.

3.6.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (6.5-1): كم بُعداً يلزم لإسقاط مليون تضمين بتشويه 10%؟

المعطيات: $n=10^6$ نقطة في $\mathbb{R}^d$، و $\varepsilon=0.1$، و $\delta=0.01$.
المطلوب: البعد k المطلوب بصيغة (33.5)، ومقارنته بقاعدة «$8\ln n/\varepsilon^2$».
الحل:

١. $\varepsilon^2-\varepsilon^3 = 0.01-0.001 = 0.009$.

٢. $\ln(n^2/\delta) = \ln(10^{12}/0.01) = \ln(10^{14}) = 14\ln 10 = 32.2362$.

٣. $k = 14328 \implies k \ge \dfrac{4\times 32.2362}{0.009} = \dfrac{128.945}{0.009} = 14327.2$.

٤. قاعدة الإبهام: $\dfrac{8\ln n}{\varepsilon^2} = \dfrac{8\times 13.8155}{0.01} = 11052$.

٥. الفرق بينهما معامل 1.30 — أي أن الصيغة المتحفّظة والقاعدة المقاربة متوافقتان في المرتبة.

النتيجة: $k \approx 1.43\times 10^4$ يكفي لحفظ كل مسافات مليون نقطة ضمن $\pm 10\%$ في المربّع ($\approx \pm 5\%$ في المسافة).
الربط بالذكاء الاصطناعي: لاحظ أن k **لا يعتمد على** d **إطلاقاً** — فإسقاط تضمينات من $d = 12288$ (نموذج لغوي ضخم) إلى $k \approx 14000$ لا يحقّق شيئاً! هذه هي النقطة التي يخطئ فيها كثيرون: JL مفيدة فقط عندما يكون $d \gg \varepsilon^{-2}\log n$. سنفحص ذلك صراحةً في المثال (6.5-6).

مثال (6.5-2): متجه واحد مقابل مليون زوج — أثر معامل $\log n$

المعطيات: $\varepsilon=0.1$، احتمال فشل مطلوب 1%.
المطلوب: k اللازم **لمتجه واحد**، ثم لمليون نقطة، ونسبة الزيادة.
الحل:

١. **متجه واحد:** $2\exp\!\big(-\tfrac{k(\varepsilon^2-\varepsilon^3)}{4}\big) \le 0.01 \implies \exp\!\big(-\tfrac{0.009k}{4}\big) \le 0.005 \implies 0.00225\,k \ge \ln 200 = 5.2983$
$\implies k \ge 2354.8 \implies k = 2355$.

٢. مليون نقطة (من 5.6-1): $k = 14328$.

٣. النسبة: $14328/2355 = 6.08$.

٤. التفسير النظري: k لمتجه واحد $\propto \ln(2/\delta)$؛ ولـ n نقطة $\propto \ln(n^2/\delta) = 2\ln n + \ln(1/\delta)$. الفرق هو $2\ln n = 2 \times 13.8155 = 27.63$ بُعداً إضافياً ✓ في اللوغاريتم — أي $4 \times 27.63/0.009 = 12280$ متوافق مع الفرق 11973.

النتيجة: حفظ **متجه واحد** يحتاج $k \approx 2355$، وحفظ **كل الأزواج** لمليون نقطة يحتاج $k \approx 14328$ — أي 6.1 أضعاف.

الربط بالذكاء الاصطناعي: هذا الفرق هو ثمن «الضمان الشامل». في التطبيقات التي تريد ضماناً على متجه واحد (مثل تقدير ناظم التدرّج للمراقبة، أو تقدير طول تضمين واحد)، يكفي k أصغر بـ 6 مرات من الضمان الشامل على كل الأزواج. اختيار نوع الضمان يحدّد التكلفة — ولا يجوز الخلط بينهما.

مثال (5.6-3): ناظم المتجه الغاوسي في بُعد 4096 — كم هو متوقَّع؟

المعطيات: $g \sim \mathcal{N}(0, I_{4096})$.
المطلوب: القيمة المتوقَّعة لناظمه، واحتمال أن ينحرف بأكثر من 5 أو 15.
الحل:

١. $\mathbb{E}\|g\|_2^2 = d = 4096 \Longrightarrow \sqrt{4096} = 64$.

٢. $\mathbb{E}\|g\|_2 \le 64$ (والقيمة الفعلية أدنى قليلاً: $63.992 = 64 - \frac{1}{2\times 64}$).

٣. من (5.6-35): $\mathbb{P}\big(\big|\|g\|_2 - \mathbb{E}\|g\|_2\big| \ge t\big) \le 2e^{-t^2/2}$.

٤. عند $t = 5$: $2e^{-12.5} = 2 \times 3.727 \times 10^{-6} = 7.45 \times 10^{-6}$.

٥. عند $t = 15$: $2e^{-112.5} \approx 2 \times 5.6 \times 10^{-49}$ — صفر عملياً.

٦. الانحراف **النسبي** المعتاد: $t/\sqrt{d} = 5/64 = 7.8\%$ عند $t = 5$ وهو احتماله $< 10^{-5}$.

النتيجة: $\|g\|_2 = 64$ بحسم؛ فاحتمالُ انحرافٍ مقداره 5 (أي 7.8%) أقلّ من 10^{-5}.

الربط بالذكاء الاصطناعي: في الأبعاد العالية «كل المتجهات العشوائية طولها متساوٍ». هذه حقيقة مضادّة للحدس لكنها حاسمة: في فضاء تضمين بُعد 4096، متجهان عشوائيان **متعامدان تقريباً** وطولاهما متماثلان. ولهذا تعمل تهيئة الأوزان الغاوسية بثبات، ولهذا يفشل مقياس «المسافة الإقليدية الخام» أحياناً في التمييز بين تضمينات عشوائية ومتعلَّمة — فالطول وحده لا يحمل معلومة في البعد العالي.

مثال (5.6-4): الناظم الطيفي مقابل الفروبنيوسي لمصفوفة أوزان مُهيَّأة عشوائياً

المعطيات: $W \in \mathbb{R}^{1024\times 768}$ بمدخلات $\mathcal{N}(0, \sigma^2)$ و $\sigma = 0.05$.

المطلوب: قارن $\mathbb{E}\|W\|_2$ بـ $\|W\|_F$ النموذجي، ومدى تركيز كلٍّ منهما.
الحل:

١. $\sqrt{m}+\sqrt{n}=\sqrt{1024}+\sqrt{768}=32+27.7128=59.7128$.

٢. $\mathbb{E}\|W\|_2 \le \sigma(\sqrt{m}+\sqrt{n})=0.05\times 59.7128=2.9856$.

٣. $\|W\|_F \approx \sigma\sqrt{mn}=0.05\sqrt{786432}=0.05\times 886.81=44.34$.

٤. معامل الفجوة: $\dfrac{\sqrt{mn}}{\sqrt{m}+\sqrt{n}}=\dfrac{886.81}{59.71}=14.85=\dfrac{44.34}{2.9856}$ ✓.

٥. التركيز: $\mathbb{P}(\|W\|_2 \ge 2.9856+t)\le e^{-t^2/(2\sigma^2)}$. عند $t=0.3$: $e^{-0.09/0.005}=e^{-18}=1.5\times10^{-8}$.

النتيجة: الناظم الطيفي $\|W\|_2 \approx 3.0$ بتركيز شديد، مقابل فرونيوسي $\|W\|_F \approx 44.3$ — فجوة بمعامل 14.9.

الربط بالذكاء الاصطناعي: هذه الفجوة هي سبب الالتباس الأكثر شيوعاً في بحوث التهيئة: تبدو $\|W\|_F = 44$ «كبيرة» لكن ثابت ليبشيتز الفعلي للطبقة هو 3. ولأن الفجوة تنمو مع العرض ($\sqrt{n}/2$ للمصفوفات المربّعة)، فإن أي تحليل يستخدم $\|W\|_F$ يزداد تشاؤماً كلما كبرت الشبكة — في حين أن السلوك الفعلي (الطيفي) ثابت. القاعدة: **حلّل بالطيفي، وحوِّل فقط عند الضرورة.**

مثال (5-6.5): اختيار تباين التهيئة بحيث يكون $\|W\|_2 = 1$

المعطيات: طبقة $m \times n$ بـ $m=n=1024$. خياران: تهيئة «He» ($\sigma=\sqrt{2/\text{fan_in}}=\sqrt{2/1024}$) وتهيئة «طيفية الوحدة».
المطلوب: الناظم الطيفي الناتج في كل خيار، وقيمة σ التي تجعل $\mathbb{E}\|W\|_2 \approx 1$.
الحل:

١. تهيئة He: $\sigma=\sqrt{2/1024}=\sqrt{0.001953}=0.044194$؛ و $\mathbb{E}\|W\|_2 \le 0.044194\times(32+32)=0.044194\times 64=2.828$.

٢. الشرط $\sigma(\sqrt{m}+\sqrt{n})=1$ يعطي $\sigma=\dfrac{1}{64}=0.015625$.

٣. نسبة التصغير المطلوبة: $0.044194/0.015625=2.828$ — أي أن تهيئة He تعطي ناظماً طيفياً ≈ 2.83 لكل طبقة.

٤. أثر التراكم على $L=12$ طبقة: $2.83^{12}=e^{12\times 1.0403}=e^{12.484}=2.64\times10^5$ (حدّ أعلى للناظم الطيفي الكلي) مقابل $1^{12}=1$ بالتهيئة الطيفية.

النتيجة: لضمان $\|W\|_2=1$ عند التهيئة استخدم $\sigma=1/(\sqrt{m}+\sqrt{n})$؛ وهو أصغر من تهيئة He بمعامل ≈ 2.8.
الربط بالذكاء الاصطناعي: هذا هو المبرّر الكمّي لتقنيات مثل «تهيئة دلتا الطيفية» و **orthogonal init** و **Fixup**: فهي تختار التباين (أو البنية) بحيث يكون الناظم الطيفي لكل طبقة ≈ 1، فلا ينفجر ناظم الشبكة الكلي أُسّياً مع العمق. الفرق بين 2.83^{12} و 1^{12} هو الفرق بين شبكة قابلة للتدريب وشبكة تحتاج تطبيعاً في كل طبقة.

مثال (6-6.5): JL لا تنفع دائماً — متى يكون $k > d$؟

المعطيات: تضمينات بـ $d = 768$، و $n = 10^6$ نقطة، و $\varepsilon = 0.1$، و $\delta = 0.1$.
المطلوب: هل يُجدي الإسقاط العشوائي تخفيضاً هنا؟
الحل:

١. $4\ln(n^2/\delta) = 4\ln(10^{12}/0.1) = 4\ln(10^{13}) = 4 \times 29.9336 = 119.734$.

٢. $k \geq \dfrac{119.734}{0.009} = 13304$.

٣. لكن $k = 13304 > d = 768$ — أي أن «البعد المخفَّض» المطلوب **أكبر من البعد الأصلي** بـ 17.3 مرة.

٤. السبب البنيوي: أعظمُ قيمة ممكنة لـ $\varepsilon^2 - \varepsilon^3$ على $(0,1)$ هي $\frac{4}{27} = 0.1481$ (عند $\varepsilon = \frac{2}{3}$)؛ فأصغرُ k يمكن أن يضمنه أيّ $\varepsilon \in (0,1)$ هو $k_{\min} = \dfrac{119.734}{0.1481} = 808$ — وهو **أيضاً** أكبر من 768.

٥. إذن: لا توجد قيمة $\varepsilon \in (0,1)$ يستطيع الإسقاط العشوائي ضمانها لهذه البيانات ببعدٍ أصغر من 768.

النتيجة: لـ $d = 768$ و $n = 10^6$، **لا يحقّق JL أي تخفيض مضمون.** تعمل JL فقط حين $d \gtrsim \varepsilon^{-2}\log n$ (هنا: $\varepsilon^{-2}\log n = 100 \times 13.8 = 1380 > 768$).

الربط بالذكاء الاصطناعي: نتيجةٌ مهمّة وكثيراً ما تُتجاهل: تقنيات «تخفيض البعد العشوائي» (المبنية على JL) تفيد في المسائل العلمية ذات d الضخم و n المعتدل (مثل إشارات الاستشعار، والجينوم، والرسوم البيانية الضخمة)، أمّا في التضمينات الدلالية حيث $d \approx 10^3$ و $n \approx 10^6$ فهي **لا تفيد.** لهذا تعتمد محرّكات ANN على التكميم و LSH و HNSW — وهي تقنيات تُضعف الضمان من «كل الأزواج» إلى «أقرب الجيران غالباً» — لا على JL.

مثال (7-6.5): اعتماد k على n لوغاريتمي — جدول

المعطيات: $\varepsilon = 0.1$، $\delta = 0.05$، و $n \in \{10^3, 10^4, 10^5, 10^6\}$.
المطلوب: البعد k المطلوب في كل حالة.
الحل:

١. الصيغة: $k = \dfrac{4\big(2\ln n + \ln(1/0.05)\big)}{0.009} = \dfrac{4(2\ln n + 2.9957)}{0.009}$.

٢. $n = 10^3$: $2\ln n = 13.8155 \Rightarrow k = \dfrac{4 \times 16.8112}{0.009} = 7472$.

٣. $n = 10^4$: $2\ln n = 18.4207 \Rightarrow k = \dfrac{4 \times 21.4164}{0.009} = 9518$.

٤. $n = 10^5$: $2\ln n = 23.0259 \Rightarrow k = \dfrac{4 \times 26.0216}{0.009} = 11565$.

٥. $n = 10^6$: $2\ln n = 27.6310 \Rightarrow k = \dfrac{4 \times 30.6267}{0.009} = 13612$.

٦. الزيادة من 10^3 إلى 10^6 (مضاعفة العدد ألف مرة): $13612/7472 = 1.82$ فقط.

النتيجة: مضاعفة عدد النقاط ألف مرة تزيد البعد المطلوب بـ 82% فقط — نموٌّ لوغاريتمي.

الربط بالذكاء الاصطناعي: هذا هو سبب قابليّة الأساليب العشوائية للتوسّع: تكلفة الضمان تنمو **لوغاريتمياً** مع حجم البيانات، لا خطّياً. ولهذا تُستخدم التخفيضات العشوائية في تعلّم الآلة على نطاق واسع (Randomized SVD، sketching للانحدار، random features) — فحجم البيانات لا يُلزم برفع البعد إلّا قليلاً.

مثال (5.6-8): القناع العشوائي (Dropout/Masking) — متى يحفظ الناظم؟

المعطيات: متجه $x \in \mathbb{R}^d$ بـ $d = 4096$، وقناع عشوائي M بمدخلات برنولية $\mathbb{P}(m_i = 1) = p = 0.9$.

المطلوب: الانحراف النسبي المعياري لـ $\|Mx\|^2$ لحالتين: متجه «مستوٍ» ومتجه «قِمّي» (شبه أحادي).

الحل:

١. $\mathbb{E}\|Mx\|^2 = p\|x\|^2 \implies \|Mx\|^2 = \sum_i m_i x_i^2$؛ والتطبيع بـ $1/p$ يجعله غير متحيّز.

٢. التباين: $\mathrm{Var}(\|Mx\|^2) = p(1-p)\sum_i x_i^4 \le p(1-p)\|x\|_\infty^2\|x\|_2^2$.

٣. الانحراف المعياري النسبي: $\dfrac{\sqrt{\mathrm{Var}}}{p\|x\|^2} \le \sqrt{\dfrac{1-p}{p}} \cdot \dfrac{\|x\|_\infty}{\|x\|_2}$.

٤. **الحالة المستوية** ($x_i = 1$ للكل): $\dfrac{\|x\|_\infty}{\|x\|_2} = \dfrac{1}{64} \implies$ الانحراف $= 0.3333 \times 0.015625 \le \sqrt{\frac{0.1}{0.9}} \times \frac{1}{64} = 0.00521$ (أي 0.52%).

٥. **الحالة القِمّية** ($x = e_1$ أحادي): $\dfrac{\|x\|_\infty}{\|x\|_2} = 1 \implies$ الانحراف 0.3333 $\le$ (أي 33%) — وبالفعل: فالإحداثي الوحيد يُحذف باحتمال 10%!

النتيجة: القناع يحفظ الناظم بدقة 0.5% للمتجهات المستوية، ويفشل بنسبة 33% للمتجهات القِمّية.

الربط بالذكاء الاصطناعي: هذا يفسّر قاعدة عملية معروفة: **القناع العشوائي (dropout) آمن على التمثيلات الكثيفة، ومدمّر على المدخلات المتناثرة** (مثل أكياس الكلمات أو الترميز الأحادي) — ولهذا تُستخدم معدّلات إسقاط مختلفة أو تُستثنى طبقة التضمين من القناع. الصيغة $\sqrt{(1-p)/p} \cdot \|x\|_\infty/\|x\|_2$ تعطي المعيار الدقيق: «مدى تركّز» المتجه هو ما يحدّد الخطورة، لا بُعده.

مثال (5.6-9): تقدير الميزات العشوائية (Random Features) — كم ميزة نحتاج؟

المعطيات: تقريب نواة بميزات عشوائية، نريد خطأً نسبياً $\varepsilon = 0.1$ على **زوج واحد** باحتمال فشل $\delta = 0.05$؛ ثم على كل أزواج $n = 5000$ نقطة.

المطلوب: عدد الميزات D في الحالتين.

الحل:

١. زوج واحد: $2\exp\!\left(-\frac{D(\varepsilon^2-\varepsilon^3)}{4}\right) \le 0.05 \Longrightarrow \exp\!\left(-\frac{0.009D}{4}\right) \le 0.025 \Longrightarrow 0.00225\,D \ge \ln 40 = 3.6889 \Longrightarrow D \ge 1640$.

٢. كل الأزواج ($n = 5000$، $\binom{n}{2} \le 1.25 \times 10^7$): $D \ge \frac{4\ln(n^2/\delta)}{0.009} = \frac{4\ln(2.5\times 10^7/0.05)}{0.009} = \frac{4\ln(5\times 10^8)}{0.009} = \frac{4 \times 20.030}{0.009} = 8902$.

٣. النسبة: $8902/1640 = 5.43$ — ثمن الضمان الشامل.

النتيجة: $D \approx 1640$ لزوج واحد، و $D \approx 8900$ لكل أزواج 5000 نقطة.

الربط بالذكاء الاصطناعي: طريقة الميزات العشوائية (Rahimi–Recht) تحوّل نواةً غير قابلة للتوسّع إلى جداء داخلي في بُعد D — فتصير تكلفة التدريب خطّية في عدد العيّنات. عدد الميزات المطلوب يتبع قانون JL نفسه: $\mathcal{O}(\varepsilon^{-2}\log n)$. ولهذا تعمل «محوّلات الطيف العشوائي» (Performers/RFA) بآلاف الميزات لا بملايين.

مثال (5.6-10): حفظ الضروب الداخلية — هل يبقى البحث بالتشابه صالحاً بعد الإسقاط؟

المعطيات: تضمينات مُطبَّعة ($\|\hat{x}\|_2 = \|\hat{y}\|_2 = 1$)؛ إسقاط JL بـ $\varepsilon = 0.1$.
المطلوب: حدّ الخطأ في التشابه بعد الإسقاط.
الحل:

١. من (5.37) مع $\|x\| = \|y\| = 1$: $\left|\langle R\hat{x},\, R\hat{y}\rangle - \langle \hat{x}, \hat{y}\rangle\right| \le \varepsilon = 0.1$.

٢. مثال: لو كان $\langle \hat{x}, \hat{y}\rangle = 0.80$ فإن $\langle R\hat{x}, R\hat{y}\rangle \in [0.70,\, 0.90]$.

٣. تحويل إلى زاوية: $\arccos(0.70) = 45.6°$ و $\arccos(0.90) = 25.8°$ — أي أن الزاوية المدركة تتراوح بين $25.8°$ و $45.6°$ بدلاً من $\arccos(0.8) = 36.9°$.

٤. تحويل إلى مسافة: من المثال (5.2-7)، $\|\hat{x} - \hat{y}\|_2 = \sqrt{2(1-\cos\theta)}$، فالمسافة الأصلية $\sqrt{0.4} = 0.632$ وبعد الإسقاط في المدى $[\sqrt{0.2},\, \sqrt{0.6}] = [0.447,\, 0.775]$.

النتيجة: التشابه بعد الإسقاط دقيق ضمن ± 0.1 (مطلقاً)، والترتيب محفوظ تقريباً لكن ليس تماماً.

الربط بالذكاء الاصطناعي: هذا يحدّد متى يجوز «الضغط قبل البحث»: إذا كانت الفجوة بين النتيجة الصحيحة والمنافِسة أصغر من ε، فالإسقاط قد يقلب الترتيب. القاعدة العملية: **يجب أن يكون هامش الثقة في الاسترجاع أكبر من** ε، وإلا فالإسقاط يدمّر الدقة. ولهذا تُستخدم الإسقاطات العشوائية للمطابقة التقريبية مع إعادة ترتيب (re-ranking) بالمتجهات الأصلية على المرشّحين الأوائل.

مثال (5.6-11): «الثبات مع العرض» — لماذا ناظم الطبقة الغاوسية لا يعتمد على d؟

المعطيات: طبقة مربّعة $d \times d$ بمدخلات $\mathcal{N}(0,\, 1/d)$ (تهيئة شائعة: التباين $= 1/\text{fan_in}$).
المطلوب: $\mathbb{E}\|W\|_2$ كدالّة في d.
الحل:

١. $\sigma = 1/\sqrt{d}$.

٢. $\mathbb{E}\|W\|_2 \le \sigma(\sqrt{d}+\sqrt{d}) = \dfrac{2\sqrt{d}}{\sqrt{d}} = 2$.

٣. التحقّق عند $d = 512$: $\sigma = 1/\sqrt{512} = 0.044194$؛ و $0.044194 \times (22.627 + 22.627) = 0.044194 \times 45.255 = 2.0$ ✓.

٤. التحقّق عند $d = 4096$: $\sigma = 1/64 = 0.015625$؛ و $0.015625 \times (64+64) = 2.0$ ✓.

٥. أمّا $\|W\|_F \approx \sigma\sqrt{d^2} = \sigma d = \sqrt{d}$ — **ينمو مع** d (64 عند $d = 4096$).

النتيجة: الناظم الطيفي 2 **مستقل عن** d؛ والفرونيوسي $\sqrt{d}$ ينمو معه.

الربط بالذكاء الاصطناعي: هذه هي المتطابقة التي تجعل التهيئة القياسية «صالحة لكل عرض»: اختيار $\sigma^2 = 1/\text{fan_in}$ يجعل الناظم الطيفي — أي ثابت ليبشيتز — ثابتاً لا يتغيّر بتوسيع الشبكة. أمّا لو ثبّتنا σ فسيكون الناظم الطيفي $\propto \sqrt{d}$ وتنفجر الشبكة مع العرض. كل مخطّطات التهيئة الحديثة (He، Glorot، Fixup، μP) هي في جوهرها اختيارات لـ σ تجعل كمية طيفية معيّنة ثابتة مع العرض.

مثال (12-6.5): Sketching للانحدار الخطي — من مليون صف إلى كم؟

المعطيات: $A \in \mathbb{R}^{N\times d}$ بـ $N = 10^6$ صف و $d = 100$ عمود؛ نريد حلّ المربّعات الصغرى بتخفيض عدد الصفوف بـ $S \in \mathbb{R}^{k\times N}$ غاوسي، بـ $\varepsilon = 0.1$ و $\delta = 0.01$.

المطلوب: عدد الصفوف بعد التخفيض k، ونسبة التسريع.

الحل:

١. من (38.5): $k = \mathcal{O}\big((d + \ln(1/\delta))/\varepsilon^2\big)$. بالثابت 4: $k = \dfrac{4(100+\ln 100)}{0.01}$.
$\dfrac{4(100+4.6052)}{0.01} = \dfrac{417.42}{0.01} = 41742$.

٢. نسبة التخفيض: $10^6/41742 = 23.96 \Longrightarrow$ تسريع ≈ 24 مرة في تشكيل النظام المُخفَّض.

٣. لاحظ أن k يعتمد على $d = 100$ و $\log(1/\delta)$ **لا على** $N = 10^6$: فالتخفيض يتحسّن (نسبةً) كلما كبر N.

٤. الضمان: لكل z في فضاء أعمدة A (بُعده $\le d+1$): $(1-\varepsilon)\|z\|^2 \le \|Sz\|^2 \le (1+\varepsilon)\|z\|^2 \Longrightarrow$ حلّ المسألة المُخفَّضة قريبٌ من حلّ المسألة الأصلية بعامل $(1+\varepsilon)/(1-\varepsilon) = 1.222$.

النتيجة: $k \approx 4.2\times 10^4$ صف تكفي لحلّ مسألة من 10^6 صف و 100 عمود بخطأ نسبي $\approx 22\%$.

الربط بالذكاء الاصطناعي: هذا هو أساس «المربّعات الصغرى المُخفَّفة» (sketched least squares) و randomized SVD في تعلّم الآلة واسع النطاق: حين يكون $N \gg d$، لا يحتاج الحل إلا إلى $\mathcal{O}(d/\varepsilon^2)$ صفوف — فتُنجز المسألة بتكلفة لا تكاد تعتمد على حجم البيانات. الفكرة نفسها خلف «تخفيض بيانات التدريب» (coresets) وضغط مجموعات البيانات الضخمة.

مثال (13-6.5): تقدير ناظم التدرّج في نموذج ضخم — التخفيض للمراقبة

المعطيات: تدرّج $g \in \mathbb{R}^{10^8}$؛ نريد تقدير $\|g\|_2$ بخطأ نسبي $\varepsilon = 0.05$ باحتمال نجاح 99%.
المطلوب: عدد الإحداثيات المُخفَّفة k، ونسبة الضغط.
الحل:

١. متجه واحد (ليس كل الأزواج): $2\exp\!\left(-\frac{k(\varepsilon^2-\varepsilon^3)}{4}\right) \le 0.01$.

٢. $\varepsilon^2 - \varepsilon^3 = 0.0025 - 0.000125 = 0.002375$.

٣. $\exp\!\left(-\frac{0.002375\,k}{4}\right) \le 0.005 \implies 0.00059375\,k \ge 5.2983 \implies k \ge 8922 \implies k = 8922$.

٤. نسبة الضغط: $10^8 / 8922 = 11208$ مرة.

٥. تحذير: هذا يحفظ **الناظم** فقط، لا المتجه نفسه — فلا يمكن استعادة g من الإسقاط.

النتيجة: $k \approx 8900$ إحداثياً تكفي لتقدير ناظم تدرّج بـ 10^8 إحداثي ضمن 5% — ضغط بأكثر من أربعة مراتب.
الربط بالذكاء الاصطناعي: تخفيض الناظم (norm sketching) مفيد للمراقبة: تتبّع $\|g\|_2$ لأجل التكيّف مع معدّل التعلّم أو الكشف عن انفجار التدرّج، بتكلفة اتصال لا تُذكر في التدريب الموزّع. أمّا **التحديث نفسه** فلا يمكن تخفيضه بهذه الطريقة — فاستعادة الاتجاه تتطلّب $k \ge d$. التمييز بين «قياس كمية قياسية» و«استعادة متجه» هو التمييز الحاسم في تصميم أنظمة الضغط.

مثال (14-6.5): إحكام JL — هل يمكن تحسين $\varepsilon^{-2}\log n$؟

المعطيات: $n = 10^6$، $\varepsilon = 0.1$. الحدّ الأعلى من (33.5) أعطى $k = 13612$ (مع $\delta = 0.05$). الحدّ الأدنى النظري $k = \Omega(\varepsilon^{-2}\log n)$.
المطلوب: قدّر حجم الفجوة بين الحدّين واستنتج.
الحل:

١. الحدّ الأدنى المقاربي: $k_{\text{lower}} \asymp \frac{\log n}{\varepsilon^2} = \frac{13.8155}{0.01} = 1381.6$ (بثابت 1).

٢. الحدّ الأعلى المحسوب: $k_{\text{upper}} = 13612$.

٣. النسبة: $13612 / 1381.6 = 9.85$ — أي أقلّ من مرتبة واحدة.

٤. الاستنتاج: الاعتماد على ε^{-2} و $\log n$ **مثالي**؛ والفجوة المتبقية ثابتٌ عددّي (بين 1 و 10 تقريباً) يمكن تحسينه بتحليل أدقّ أو بمصفوفات إسقاط مُهيَّكلة (مثل تحويلات هادامار السريعة المقعّبة).

٥. لكن لا يمكن تحسين الاعتماد على ε: فالانتقال من $\varepsilon = 0.1$ إلى $\varepsilon = 0.05$ يضاعف k أربع مرات في الحدّين معاً.

النتيجة: صيغة $k \asymp \varepsilon^{-2} \log n$ مثالية من حيث الاعتماد الوظيفي؛ وتحسينها ممكن في الثابت فقط.

الربط بالذكاء الاصطناعي: معرفة أن الحدّ مثاليّ تُوجّه الجهد الهندسي بشكل صحيح: لا جدوى من البحث عن إسقاط «أفضل جوهرياً»؛ الجهد المفيد يذهب إلى (أ) تحسين الثابت، (ب) استخدام إسقاطات مُهيَّكلة (Fast JL: هادامار + قناع متناثر) تخفض **التكلفة الحسابية** من $\mathcal{O}(kd)$ إلى $\mathcal{O}(d \log d)$، و (ج) إضعاف الضمان إلى «أقرب الجيران» كما في LSH.

مثال (5.6-15): تكميم عشوائي مقابل حدّ أسوأ حالة — الفجوة بمعامل ≈ 20

المعطيات: مصفوفة $W \in \mathbb{R}^{512 \times 512}$، خطوة تكميم $\Delta = 2^{-7} = 0.0078125$ (راجع المثال 5.3-13).

المطلوب: قارن حدّ أسوأ حالة (الناتج من التكافؤ) بالقيمة النموذجية (الناتجة من تركيز ناظم المصفوفة العشوائية).

الحل:

١. خطأ الإحداثي: منتظم على $[-\Delta/2, \Delta/2]$، بانحراف معياري $\sigma_e = \dfrac{\Delta}{2\sqrt{3}} = \dfrac{0.0078125}{3.4641} = 0.0022555$.

٢. حدّ أسوأ حالة (من 5.3-13): $\|\Delta W\|_2 \le \|\Delta W\|_F \le \sqrt{mn}\,\frac{\Delta}{2} = 512 \times 0.00390625 = 2.0$.

٣. القيمة النموذجية بـ (5.6-3): $\mathbb{E}\|\Delta W\|_2 \approx \sigma_e(\sqrt{m} + \sqrt{n}) = 0.0022555 \times (22.627 + 22.627) = 0.0022555 \times 45.255 = 0.1021$.

٤. الفجوة: $2.0 / 0.1021 = 19.6$.

٥. سبب الفجوة: حدّ التكافؤ يفترض أن كل الإحداثيات الـ 262144 تتآمر في الاتجاه الأسوأ، أمّا الخطأ العشوائي فيتوزّع على كل الاتجاهات فيتوسّط جزءٌ كبيرٌ منه.

٦. التركيز: $\mathbb{P}(\|\Delta W\|_2 \ge 0.1021 + t) \le e^{-t^2/(2\sigma_e^2)}$؛ عند $t = 0.05$ $=: e^{-0.0025/(2\times 5.087\times 10^{-6})} = e^{-245.7}$ — احتمالٌ ضئيل.

النتيجة: الناظم الطيفي الفعلي لخطأ التكميم $0.10 \approx$ بتركيز شديد، مقابل حدّ أسوأ حالة $2.0 =$.

الربط بالذكاء الاصطناعي: هذه الفجوة بمعامل $20 \approx$ هي المبرّر الكامل لتحليل «التكميم بعد التدريب» (PTQ) بحدود احتمالية لا بحدود أسوأ حالة: فالخطأ العشوائي لا يتآمر. وهي أيضاً تفسّر لماذا تعمل الأوزان المُكَمَّمة إلى INT8 عملياً (بخطأ طيفي $0.1 \approx$) رغم أن التحليل الأسوأ-حالة يوحي بكارثة. القاعدة: **للأخطاء المنهجية (انحياز، سوء تكييف) استخدم حدود أسوأ حالة؛ وللأخطاء العشوائية (تكميم، ضغط، تقريب) استخدم التركيز.**

4.6.5 أخطاء شائعة في تركيز النواظم ولمّة JL

#	الخطأ الشائع	لماذا هو خطأ؟	التصحيح
1	افتراض أن JL تخفّض البعد دائماً	تتطلّب $k \gtrsim \varepsilon^{-2}\log n$؛ وقد يكون ذلك $> d$	قارن k بـ d قبل الاعتماد عليها (مثال 6-5.5)
2	الخلط بين $\pm\varepsilon$ على **المسافة** وعلى **مربّعها**	JL على المربّع؛ المسافة ضمن $\approx 1 \pm \varepsilon/2$	حدّد دائماً أيَّ كمية يُقاس التشويه عليها
3	استخدام ضمان «متجه واحد» لكل الأزواج	الفرق معامل $k \approx 6$ في $\ln(n^2/\delta)$ لا $\ln(2/\delta)$	استخدم $\ln(n^2/\delta)$
4	توقّع أن $\|W\|_F$ يعبّر عن سلوك الطبقة	$\|W\|_F \approx \sigma\sqrt{mn}$ و $\|W\|_2 \approx \sigma(\sqrt{m}+\sqrt{n})$	استخدم الطيفي للتحليل؛ والفجوة $\approx \sqrt{mn}/(\sqrt{m}+\sqrt{n})$
5	ظنّ أن ناظم المتجه العشوائي يتقلّب كثيراً	الانحراف النسبي $\approx 1/\sqrt{d}$	استخدم (35.5): التركيز أُسّي
6	تثبيت σ مع تغيير العرض	يجعل $\|W\|_2 \propto \sqrt{\text{width}}$	اختر $\sigma \propto 1/\sqrt{\text{fan_in}}$ أو $1/(\sqrt{m}+\sqrt{n})$
7	استخدام ناظم أقصى عنصر مع إسقاطات عشوائية	ليس متضاعفاً تحتياً ولا يتركّز بالطريقة نفسها	استخدم ℓ_2/الطيفي
8	افتراض أن التخفيض يحفظ **المتجه** لا كميةً قياسية	استعادة الاتجاه تتطلّب $k \geq d$	ميّز بين تقدير الناظم واستعادة المتجه (13-6.5)
9	تجاهل نسبة تركّز المتجه عند القناع العشوائي	للمتجهات القِمَمية يصل الانحراف إلى 33%	استخدم $\sqrt{(1-p)/p}\cdot\|x\|_\infty/\|x\|_2$
10	السعي إلى تحسين اعتماد k على ε أو n	الحدّ $\varepsilon^{-2}\log n$ مثاليّ	حسّن الثابت أو التكلفة الحسابية (Fast JL لا المرتبة)

مجموعة أ: المفردات ومتراجحات كوشي–شفارتس وهولدر

ت (5-1): بيّن أن الدالة $\|x\| = |x_1|$ على $\mathbb{R}^2$ **ليست** ناظماً. ما المسلّمة التي تنكسر؟

الجواب: تنكسر (N1): $\|(0,1)\| = 0$ لكن $(0,1) \neq 0$. هي شبه ناظم فقط.

ت (5-2): احسب $\|x\|_1$ و $\|x\|_2$ و $\|x\|_\infty$ لـ $x = (3,-4,0,1)^\top$ ورتّبها.

الجواب: 8، $\sqrt{26} = 5.099$، 4. الترتيب: $8 \geq 5.099 \geq 4$ ✓.

ت (5-3): تحقّق من كوشي–شفارتس لـ $x = (1,2,2)^\top$ و $y = (2,-1,2)^\top$، ثم احسب الزاوية.

الجواب: $\langle x,y\rangle = 2-2+4 = 4$؛ $\|x\|_2 = 3$، $\|y\|_2 = 3$؛ $4 \leq 9$ ✓؛ $\cos\theta = 4/9 = 0.4444 \Rightarrow \theta = 63.6°$.

ت (5-4): ما الأُسّ المترافق لـ $p = 3$؟ ثم استخدم هولدر لحساب سقف $\sum_i |x_i y_i|$ حيث $x = (1,2,3)$ و $y = (4,5,6)$.

الجواب: $q = 3/2$. $\|x\|_3 = (1+8+27)^{1/3} = 36^{1/3} = 3.3019$؛ $\|y\|_{3/2} = (4^{1.5}+5^{1.5}+6^{1.5})^{2/3} = (8+11.180+14.697)^{2/3} = (33.877)^{2/3} = 10.245$. **القيمة الفعلية** $= 4+10+18 = 32 \leq 33.83$ ✓. **السقف** $= 33.83$.

ت (5-5): ℓ_2 ثنوي نفسه. استخدم ذلك لحساب أقصى تغيّر في $w^\top x$ تحت $\|x\|_2 \leq 0.2$ عندما $\|w\|_2 = 7$.

الجواب: $|\Delta| \leq \|w\|_2\|x\|_2 = 7 \times 0.2 = 1.4$، ويُبلَغ بـ $x = 0.2\,w/\|w\|_2$.

ت (5-6): بيّن أن $\|x\|_1 \leq \sqrt{s}\|x\|_2$ حيث $s = |\operatorname{supp}(x)|$ باستخدام كوشي–شفارتس مباشرةً.

الجواب: $\sum_{i\in S}|x_i|\cdot 1 \leq \sqrt{\sum_{i\in S}x_i^2}\sqrt{|S|} = \sqrt{s}\|x\|_2$.

مجموعة ب: تكافؤ النواظم

ت (5-7): احسب حدود $\|x\|_1$ في $\mathbb{R}^{100}$ إذا كان $\|x\|_2 = 2$.

الجواب: $2 \le \|x\|_1 \le 10 \times 2 = 20$.

ت (5-8): متى يُبلَغ الحدّ الأعلى $\|x\|_1 = \sqrt{n}\|x\|_2$؟ ومتى الأسفل؟

الجواب: الأعلى عندما تتساوى كل $|x_i|$ (مثل $x = \mathbf{1}$)؛ والأسفل عندما يكون غير الصفري إحداثياً واحداً ($x = ce_i$).

ت (5-9): متجه متناثر في $\mathbb{R}^{10000}$ بـ $s = 25$ إحداثياً غير صفري و $\|x\|_2 = 5$. احسب حدّ $\|x\|_1$ المتناثر وقارنه بالكثيف.

الجواب: متناثر: $\le 5\sqrt{25} = 25$؛ كثيف: $5\sqrt{10000} = 500 \le$؛ تحسين بمعامل 20.

ت (5-10): إن كان $\|e_k\|_2 \le 0.8^k \|e_0\|_2$ و $n = 100$، فكم تكراراً إضافياً يكلّفه قياس الخطأ بـ ℓ_∞؟

الجواب: $\dfrac{\ln \sqrt{100}}{\ln(1/0.8)} = \dfrac{2.3026}{0.2231} = 10.32 \Rightarrow \approx 11$ تكراراً إضافياً.

ت (5-11): بيّن أن $\|x\|_\infty \le \|x\|_2 \le \|x\|_1 \le n\|x\|_\infty$ لكل $x \in \mathbb{R}^n$.

الجواب: الحدّان الأولان من (13.5)؛ والأخير من $|x_i| \le \|x\|_\infty$ لكل i فـ $\|x\|_1 = \sum |x_i| \le n\|x\|_\infty$.

ت (5-12): لماذا لا يعطي تنظيم $\|w\|_2$ تناثراً بينما يعطيه تنظيم $\|w\|_1$؟

الجواب: كرة ℓ_1 لها أركان حادّة على محاور الإحداثيات، فنقطة التماس مع مستوى القيد تقع غالباً على محور (إحداثيات صفرية)؛ وكرة ℓ_2 ملساء فنقطة التماس عامّة الموضع.

مجموعة ج: النواظم المصفوفية

ت (5-13): احسب $\|A\|_1$ و $\|A\|_\infty$ لـ $A = \begin{pmatrix} 1 & -2 \\ 3 & 1 \end{pmatrix}$.

الجواب: مجاميع الأعمدة: 4 و $3 \Rightarrow \|A\|_1 = 4$؛ مجاميع الصفوف: 3 و $4 \Rightarrow \|A\|_\infty = 4$.

ت (5-14): احسب $\|A\|_2$ للمصفوفة نفسها.

الجواب: $A^\top A = \begin{pmatrix} 10 & 1 \\ 1 & 5 \end{pmatrix}$، الأثر 15، المحدِّد 49؛ $\lambda = \frac{15 \pm \sqrt{225-196}}{2} = \frac{15 \pm 5.3852}{2} \Rightarrow \lambda_1 = 10.1926$؛ $\|A\|_2 = \sqrt{\lambda_1} = 3.1926$.

ت (5-15): تحقّق أن $\rho(A) \le \|A\|_2$ للمصفوفة نفسها.

الجواب: القيم الذاتية: $\lambda = 1 \pm i\sqrt{6} \Rightarrow \lambda^2 - 2\lambda + 7 = 0$، $|\lambda| = \sqrt{7} = 2.6458 \le 3.1926$ ✓.

ت (5-16): بيّن أن $\|A\|_2 \le \sqrt{\|A\|_1 \|A\|_\infty}$ للمصفوفة نفسها.

الجواب: $\sqrt{4 \times 4} = 4 \ge 3.1926$ ✓.

ت (5-17): إن كان $\|A\|_2 = 0.4$، فاحدُد $\|(I - A)^{-1}\|_2$ وفسّر معنى الرقم.

الجواب: $\le \frac{1}{1-0.4} = 1.667$. المعنى: تضخّم التدرّج عبر طبقة ضمنية لا يتجاوز 1.667 ضعفاً.

ت (5-18): مصفوفة A قيمها المفردة $(10,\ 2,\ 0.5)$. احسب $\kappa_2(A)$ والخطأ النسبي الأقصى في الحل عند اضطراب نسبي 10^{-4}.

الجواب: $\kappa_2 = 10/0.5 = 20 \implies$ خطأ نسبي $\le 20 \times 10^{-4} = 2 \times 10^{-3}$ أي 0.2%.

ت (5-19): بيّن أن $\|A\|_{\max}$ ليس متضاعفاً تحتياً بمثال.

الجواب: $A = B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$: $\|A\|_{\max}\|B\|_{\max} = 1$ لكن $\|AB\|_{\max} = 2 > 1$.

ت (5-20): لماذا $\|I_n\|_F = \sqrt{n}$ بينما $\|I_n\|_2 = 1$؟

الجواب: الفرونيوسي يجمع مربّعات كل العناصر (n عنصراً قيمة كلٍّ 1)؛ والطيفي يقيس أقصى تمديد (والتحويلُ الوحدوي لا يمدّد شيئاً).

مجموعة د: نواظم شاتن وفون نيومان

ت (5-21): مصفوفة قيمها المفردة $(6,\ 3,\ 1)$. احسب $\|A\|_*$ و $\|A\|_F$ و $\|A\|_2$ والرتبة الفعّالة.

الجواب: 10؛ $\sqrt{46} = 6.782$؛ 6؛ $\text{erank} = 100/46 = 2.17$.

ت (5-22): مصفوفة شبه موجبة قيمها الذاتية $(9,\ 4,\ 1)$. ما ناظمها النووي بلا SVD؟

الجواب: $\|A\|_* = \text{tr}(A) = 14$ (لأن $A \succeq 0$ فالقيم المفردة = القيم الذاتية).

ت (5-23): احسب سقف فون نيومان لـ $\sigma(A) = (5, 2)$ و $\sigma(B) = (3, 1)$. ما القيمة إذا كانت المحاور متطابقة؟

الجواب: $5 \times 3 + 2 \times 1 = 17$؛ وبالمحاور المتطابقة $|\text{tr}(A^\top B)| = 17$ (يبلغ السقف).

ت (5-24): الترتيب المعكوس يعطي ماذا؟ قارن.

الجواب: $5 \times 1 + 2 \times 3 = 11$ (الأدنى)؛ فالمدى $[11, 17]$.

ت (5-25): تحديث LoRA رتبته 1: $\Delta W = uv^\top$ بـ $\|u\|_2 = 3$ و $\|v\|_2 = 4$. احسب نواظمه الثلاثة.

الجواب: $\sigma = (12) \implies \|\Delta W\|_* = \|\Delta W\|_F = \|\Delta W\|_2 = 12$.

ت (5-26): بيّن أن $|\text{tr}(A^\top B)| \le \|A\|_2 \|B\|_*$ هي حالة خاصة من هولدر لشاتن.

الجواب: بـ $(p, q) = (\infty, 1)$: $\frac{1}{\infty} + \frac{1}{1} = 1$ ✓؛ و $\|A\|_{S_\infty} = \|A\|_2$، $\|B\|_{S_1} = \|B\|_*$.

مجموعة هـ: التركيز وJL

ت (5-27): متجه غاوسي في $\mathbb{R}^{10000}$. ما ناظمه المتوقَّع؟ وما احتمال انحرافه بـ 20؟

الجواب: $\sqrt{10000} = 100$؛ $\mathbb{P} \le 2e^{-200} \approx 2.8 \times 10^{-87}$ — صفر عملياً.

ت (5-28): مصفوفة $W \in \mathbb{R}^{2048\times 2048}$ بمدخلات $\mathcal{N}(0,\, 1/2048)$. ما ناظمها الطيفي المتوقَّع؟

الجواب: $\sigma = 1/\sqrt{2048} = 0.022097$؛ $\mathbb{E}\|W\|_2 \le 0.022097 \times (45.255 + 45.255) = 2.0$.

ت (5-29): ما $\|W\|_F$ النموذجي للمصفوفة نفسها؟ وما معامل الفجوة؟

الجواب: $\sigma\sqrt{mn} = 0.022097 \times 2048 = 45.25$؛ معامل الفجوة $= 45.25/2 = 22.6 = \sqrt{2048}/2$ ✓.

ت (5-30): $n = 10^4$ نقطة و $\varepsilon = 0.2$ و $\delta = 0.05$. احسب k المطلوب لـ JL.

الجواب: $\varepsilon^2 - \varepsilon^3 = 0.04 - 0.008 = 0.032$؛ $\ln(n^2/\delta) = \ln(10^8/0.05) = \ln(2 \times 10^9) = 21.416$؛ $k \ge 4 \times 21.416/0.032 = 2677 \Rightarrow k = 2677$.

1.8.5 جدول النظريات الخمس

#	النظرية	الصيغة الحاكمة	متى تستخدمها؟
2.5	كوشي–شفارتس / هولدر / مينكوفسكي	$\lvert\langle x,y\rangle\rvert \le \|x\|_p\|y\|_q$ بالترافق $\frac{1}{p}+\frac{1}{q}=1$	لضبط أيّ جداء داخلي: التشابه، القربات، الحدود الأساسية
3.5	تكافؤ النواظم	$c\|x\|_\alpha \le \|x\|_\beta \le C\|x\|_\alpha$، والثوابت تعتمد على n (أو s)	للتحويل بين النواظم، ولتفسير «ثمن البعد»
4.5	النواظم المستحثة والتضاعف التحتي	$\|AB\| \le \|A\|\|B\|$، و $\rho(A) \le \|A\|$، و $\|A\|_2 = \sigma_1$	لتحليل الاستقرار، وتراكم الأخطاء، وليبشيتز
5.5	شاتن وفون نيومان	$\lvert\mathrm{tr}(A^\top B)\rvert \le \langle\sigma(A),\sigma(B)\rangle \le \|A\|_{S_p}\|B\|_{S_q}$	للرتبة المنخفضة، ولضرب مصفوفتين، وللرتبة الفعّالة
6.5	تركيز النواظم وJL	$k = \mathcal{O}(\varepsilon^{-2}\log n)$ يحفظ كل المسافات؛ و $\|W\|_2 \approx \sigma(\sqrt{m}+\sqrt{n})$	للأبعاد العالية، وللأخطاء العشوائية، وللإسقاطات

2.8.5 خمسة مبادئ حاكمة

١. **الناظم ليس مقياساً محايداً — هو قرار.** اختيار الناظم يحدّد شكل كرة الوحدة، وشكل الكرة يحدّد نوع الحل (تناثر، رتبة منخفضة، استقرار، أسوأ حالة).

٢. **الناظم الثنوي هو «ما يقابل» الناظم الأصلي.** كل حدّ هو جداء: $\|x\|_* \cdot \|w\|$؛ ولا معنى لتحسين أحدهما دون الآخر.

٣. **التكافؤ يحمي «المقاربية»، والثوابت تحكم «السرعة».** الرقم ρ لا يتغيّر بتغيير الناظم، لكن عدد الخطوات يتغيّر بمقدار $\frac{\ln\sqrt{n}}{\ln(1/\rho)}$.

٤. **المصفوفة مشغّل لا قائمة.** حلّل بـ $\|A\|_2$؛ واحسب بـ $\|A\|_F$ أو بحدود رخيصة؛ ولا تخلط بينهما بلا معامل.

٥. **للأخطاء المنهجية حدودُ أسوأ حالة؛ وللأخطاء العشوائية حدودُ التركيز.** الخلط بينهما ينتج إمّا كارثةً متوهّمة (مبالغة) وإمّا أماناً زائفاً (تفاؤل).

3.8.5 الطريق إلى الأجزاء التالية

الموضوع في هذا الفصل	أين يظهر لاحقاً؟
النواظم والمتراجحات	**الجزء الرابع (التحسين):** تحليل التقارب، والتدرّج المقيَّد، وثوابت ليبشيتز للمُحسِّنات
الناظم الثنوي و $\|w\|\|x\|_*$	**الجزء السادس (نظرية التعلّم):** تعقيد راديماخر، وحدود التعميم القائمة على الهامش
$\|W\|_2$ والاستقرار	**الجزء السابع (رياضيات التعلّم العميق):** الشبكات مقيَّدة ليبشيتز، والتطبيع الطيفي، وNTK
الرتبة الفعّالة والنووي	**الجزء السابع:** الضغط، والتحليل الطيفي للتمثيلات، وانهيار التمثيل
تركيز النواظم وJL	**الجزء الثامن:** الإسقاطات العشوائية، والطوبولوجيا الحسابية، والتضمينات منخفضة البعد
مسافات على التوزيعات	**الجزء الخامس (نظرية المعلومات) والجزء الثامن (نقل الأمثل):** TV، KL، Wasserstein

الفصل القادم: التحليل العددي والاستقرار الحسابي — حيث نحوّل متراجحات هذا الفصل إلى **خوارزميات**: كيف نحسب SVD و QR و factorization بثبات، وكيف تتراكم أخطاء النقطة العائمة، ولماذا يُعدّ رقم الحالة — لا دقة الحاسوب — هو الحدّ الحقيقي لما يمكن حسابه.

الرمز	المعنى	القسم
$\|\cdot\|$	ناظم عام	1.5
$\|\cdot\|_p$	ناظم ℓ_p	1.5
$\|\cdot\|_1,\ \|\cdot\|_2,\ \|\cdot\|_\infty$	مانhattan، إقليدي، تشيبيشيف	1.5
$\|\cdot\|_G$	ناظم آتٍ من مصفوفة قياس G	1.5
$d(x,y)$	مسافة / مترية	1.5
$\langle x,y\rangle$	ضرب داخلي	1.5
$\|\cdot\|_*$	الناظم الثنوي	2.5
p, q	أُسّان مترافقان: $\frac{1}{p}+\frac{1}{q}=1$	2.5
θ	الزاوية بين متجهين	2.5
a, b	متغيّرا لمّة يونغ	2.5
$c,\ C$	ثابتا التكافؤ بين ناظمين	3.5
S_α	سطح كرة الوحدة	3.5
s	مستوى التناثر $(\|\operatorname{supp}(x)\|)$	3.5
$\operatorname{supp}(x)$	دعم المتجه	3.5
$\|A\|_{\alpha\to\beta}$	ناظم مستحث من α إلى β	4.5
$\|A\|_2$	الناظم الطيفي $= \sigma_1$	4.5
$\|A\|_1$	ناظم المشغّل ℓ_1 = أكبر مجموع عمود	4.5
$\|A\|_\infty$	ناظم المشغّل ℓ_∞ = أكبر مجموع صف	4.5
$\|A\|_F$	الناظم الفروبنيوسي	4.5
$\|A\|_{\max}$	ناظم أقصى عنصر مطلق	4.5
$\rho(A)$	نصف القطر الطيفي	4.5
$\kappa(A)$	رقم الحالة	4.5
$\sigma_i(A)$	القيمة المفردة رقم i	4.5
r	الرتبة	4.5
$\|A\|_{S_p}$	ناظم شاتن من الرتبة p	5.5
$\|A\|_*$	الناظم النووي $= \|A\|_{S_1}$	5.5
$\operatorname{tr}(\cdot)$	الأثر	5.5
$U,\ V$	المصفوفتان الوحديّتان في SVD	5.5
Σ	مصفوفة القيم المفردة القطرية	5.5
$\operatorname{erank}(A)$	الرتبة الفعّالة $= \|A\|_*^2/\|A\|_F^2$	5.5
R	مصفوفة إسقاط عشوائي $k\times d$	6.5
k	البعد بعد الإسقاط	6.5
ε	تشويه JL (على مربّع المسافة)	6.5
δ	احتمال الفشل	6.5
χ^2_k	توزيع مربّع كاي بـ k درجة حرية	6.5
g	متجه غاوسي قياسي	6.5
σ	انحراف معياري لمدخلات المصفوفة العشوائية	6.5
d_0	بُعد الفضاء الجزئي في تضمين الفضاءات الجزئية	6.5

١. A.-L. Cauchy, (1821). *Cours d'Analyse de l'École Polytechnique Royale* — متراجحة كوشي–شفارتس.

٢. H. A. Schwarz, (1888). *Über ein Flächeninhalts kleinsten Flächen betreffendes Problem der Variationsrechnung*.

٣. O. Hölder, (1889). «Über einen Mittelwerthssatz». *Nachrichten Göttinger*.

٤. H. Minkowski, (1896). *Zahlen der Geometrie*.

٥. H. W. Young, (1912). «On classes of functions and their Fourier series». *Proc. R. Soc. A*.

٦. G. Pólya, E., J. Littlewood, H., G. Hardy, (1934). *Inequalities*. University Cambridge Press — المرجع الكلاسيكي للمتراجحات.

٧. R. Bellman, F., E. Beckenbach, (1961). *An Introduction to Inequalities*. MAA.

٨. M. J. Steele, (2004). *The Cauchy–Schwarz Master Class*. University Cambridge Press.

٩. R. C. Johnson, A., R. Horn, (2012). *Matrix Analysis*, 2nd ed. University Cambridge Press — النواظم المصفوفية ونواظم شاتن.

١٠. F. C. Loan, Van H., G. Golub, (2013). *Matrix Computations*, 4th ed. Johns Hopkins — النواظم وأرقام الحالة.

١١. J. N. Higham, (2002). *Accuracy and Stability of Numerical Algorithms*, 2nd ed. SIAM.

١٢. D. Bau, N., L. Trefethen, (1997). *Numerical Linear Algebra*. SIAM.

١٣. J. Neumann, von (1937). «Some matrix-inequalities and metrization of matric-space». *Univ. Tomsk Rev.*

١٤. L. Mirsky, (1960). «Symmetric gauge functions and unitarily invariant norms». *Q. J. Math.*

١٥. R. Bhatia, (1997). *Matrix Analysis*. Springer — نواظم شاتن ومتراجحات الأثر.

١٦. M. Fazel, (2002). *Matrix Rank Minimization with Applications*, PhD Thesis, Stanford — النووي غلافاً مقعّباً للرتبة.

١٧. A. P. Parrilo, M., Fazel, B., Recht, (2010). «Guaranteed minimum-rank solutions via nuclear norm minimization». *SIAM Rev.*

١٨. B. Recht, J., E. Candès, (2009). «Exact matrix completion via convex optimization». *Found. Comput. Math.*

١٩. T. Tao, J., E. Candès, (2010). «The power of convex relaxation: near-optimal matrix completion». *IEEE Trans. Inform. Theory*.

٢٠. J. Lindenstrauss, B., W. Johnson, (1984). «Extensions of Lipschitz mappings into a Hilbert space». *Contemp. Math.* 26.

٢١. A. Gupta, S., Dasgupta, (2003). «An elementary proof of a theorem of Johnson and Lindenstrauss». *Random Structures & Algorithms*.

٢٢. N. Alon, (2003). «Problems and results in extremal combinatorics — I». *Discrete Math*. JL. حدود سفلى لـ

٢٣. J. Nelson, G., K. Larsen, (2017). «Optimality of the Johnson–Lindenstrauss lemma». *FOCS*.

٢٤. Y. Gordon, (1985). «Some inequalities for Gaussian processes and applications». *Israel J. Math*.

٢٥. Q. Y. Yin, D., Z. Bai, (1993). «Limit of the smallest eigenvalue of a large-dimensional sample covariance matrix». *Ann. Probab*.

٢٦. R. Vershynin, (2018). *High-Dimensional Probability*. Cambridge University Press — التركيز والمصفوفات العشوائية.

٢٧. Boucheron, S., Lugosi, G., Massart, P. (2013). *Concentration Inequalities*. Oxford University Press.

٢٨. P. D. Woodruff, (2014). «Sketching as a Tool for Numerical Linear Algebra». *Found. Trends Theor. Comput. Sci*.

٢٩. B. Recht, A., Rahimi, (2007). «Random features for large-scale kernel machines». *NeurIPS*.

٣٠. W. M. Mahoney, (2011). «Randomized Algorithms for Matrices and Data». *Found. Trends Mach. Learn*.

تمّ الفصل الخامس. في الفصل السادس ننتقل من **متراجحات القياس** إلى **خوارزميات الحساب**: كيف نحوّل هذه المتراجحات إلى عمليات مستقرّة عددياً، وكيف نقرأ «ماذا يحدث فعلاً» داخل حساب النقطة العائمة.

التحليل العددي والاستقرار الحسابي

الهدف من الفصل

أن تفهم **ماذا يحدث فعلاً** داخل الحاسوب حين يحسب. في الفصل الخامس أعطينا متراجحات «مثالية» على أعداد حقيقية دقيقة لانهائياً. هذا الفصل يسأل السؤال الذي يُسقط كل متراجحة جميلة على أرض الواقع: **ماذا لو كان كل رقم في الحاسوب يحمل خطأً صغيراً؟** متى يبقى الخطأ صغيراً؟ ومتى ينفجر فيُخرج نموذجاً «يتعلّم» لكن نتائجه هراء؟

لماذا هذا الفصل هو «فجوة الواقع» في الكتاب؟

كل خوارزمية في تعلم الآلة — التدرّج العكسي، تربيع المربعات الصغرى، انتباه (attention) المحوّلات، تهيئة الأوزان، القياس الكمّي (quantization)، التدريب بالدقة المختلطة (mixed precision)، حساب الانتروبيا المتقاطعة — هي في نهاية المطاف **سلسلة من عمليات النقطة العائمة**. والفرق بين نموذج يتدرّب ونموذج يعطي NaN من الخطوة الأولى ليس فرقاً في «المعرفة الرياضية» بل في **الاستقرار العددي**.

الظاهرة في الذكاء الاصطناعي	السبب العددي
ظهور NaN فجأة أثناء التدريب	فيضان (overflow) في exp أو قسمة $0/0$
loss لا ينزل مع أنه محسوب صحيحاً	إلغاء كارثي أو تراكم خطأ في الجمع على دفعات ضخمة
نتائج غير قابلة للتكرار بين CPU و GPU	ترتيب الجمع مختلف $\Rightarrow$ أخطاء تقريب مختلفة (غير تجميعية)
fp16 ينفجر و fp32 يعمل	فقدان الخانات: فقدنا $\log_{10}\kappa$ خانات بسبب رقم الحالة
تدريب غير مستقر مع طبقات عميقة	حاصل نواظم المشغّل $\prod_k \|W_k\|_2$ — تضخّم أسي
حلّ المربعات الصغرى «دقيق» نظرياً وخطأ عملياً	المعادلات السوية تربّع رقم الحالة — $\kappa(A^\top A)=\kappa(A)^2$
انهيار الأوزان إلى صفر (underflow) في fb16	أصغر عدد مطبّعي 1.18×10^{-38} والتدرّجات الصغيرة تختفي
فروق شاسعة بين إطارين (PyTorch/TF) في الأرقام العشرية	ترتيب العمليات وخوارزميات الجمع (Kahan/pairwise)

خريطة الفصل

القسم	الموضوع	القوانين/النظريات	عدد الأمثلة المحلولة
1.6	المفردات: نموذج النقطة العائمة، الخطأ الأمامي/الخلفي، التكييف	(1.6)–(7.6)	—
2.6	**القانون الأساسي لتحليل الخطأ**: الخطأ الأمامي $\lesssim \kappa\times$ الخطأ الخلفي	(8.6)–(13.6)	15
3.6	**الإلغاء الكارثي وتراكم الخطأ في الجمع** (Kahan)	(14.6)–(19.6)	15
4.6	**استقرار التحويلات المتعامدة** و QR Householder	(20.6)–(25.6)	15
5.6	**تكييف المربعات الصغرى**: $\kappa(A^\top A)=\kappa(A)^2$ وحدّ غولوب–ويلكنسون	(26.6)–(31.6)	15
6.6	**عامل النموّ في LU** والتنقيح التكراري (iterative refinement)	(32.6)–(37.6)	15
7.6	**استقرار softmax/log-sum-exp** والدقة المختلطة	(38.6)–(43.6)	15
8.6	تمارين محلولة ومفتوحة (30 تمريناً)	—	—
9.6	خلاصة الفصل	—	—
10.6	فهرس الرموز	—	—
11.6	المراجع	—	—

كيف تقرأ هذا الفصل

كل نظرية تأتي في **أربع طبقات** إلزامية:

١. **الصياغة الرياضية الرسمية** داخل كتلة LaTeX مستقلة باتجاه LTR.

٢. **جدول الرموز:** كل رمز ومعامل يُشرح منفرداً.

٣. **رسم هندسي** (SVG) يشرح المعنى البصري.

٤. **خمسة عشر مثالاً محلولاً من الواقع** — كل مثال: المعطيات ← المطلوب ← الحل خطوة بخطوة ← النتيجة ← الربط بالذكاء الاصطناعي.

ثم: برهان، شروط صحّة، أخطاء شائعة، ثم تمارين.

1.1.6 نموذج النقطة العائمة (floating-point model)

الحاسوب لا يخزّن الأعداد الحقيقية، بل مجموعة منتهية $\mathbb{F} \subset \mathbb{R}$. عملية التقريب $\mathrm{fl} : \mathbb{R} \to \mathbb{F}$ تخضع للنموذج القياسي التالي (نموذج ويلكنسون):

$$\mathrm{fl}(x \ \mathrm{op} \ y) = (x \ \mathrm{op} \ y)(1+\delta), \qquad |\delta| \le u, \qquad \mathrm{op} \in \{+, -, \times, \div\} \tag{1.6}$$

$$u = \begin{cases} \frac{1}{2}\beta^{1-t} & \text{round-to-nearest (أكثر الحالات)} \\ \beta^{1-t} & \text{round-toward-zero} \end{cases} \tag{2.6}$$

الرمز	المعنى	القيمة النموذجية
$\mathrm{fl}(\cdot)$	دالة التقريب إلى أقرب عدد مُمثَّل في $\mathbb{F}$	—
x, y	الأعداد الحقيقية الدقيقة المُدخلة في العملية	—
op	إحدى العمليات الحسابية الأربع الأساسية	$+, -, \times, \div$
δ	الخطأ النسبي المُدخل في **عملية واحدة**	$\lvert\delta\rvert \le u$
u	**وحدة التقريب** (unit roundoff) — نصف الفجوة النسبية بين عددين متجاورين	انظر الجدول أدناه
β	أساس التمثيل (دائماً 2 في الأجهزة الحديثة)	2
t	عدد خانات الجوهر (significand/precision) بالأساس β	24 في fp32، 53 في fp64
$\frac{1}{2}$	معامل «أقرب جار»: أقصى انحراف هو نصف المسافة بين جارين	—

قيم عملية يجب حفظها:

الصيغة	t	$u = \frac{1}{2}\beta^{1-t}$	أصغر مطبّعي موجب	أكبر عدد	الخانات العشرية الصحيحة
fbloat16	8	3.91×10^{-3}	1.18×10^{-38}	3.39×10^{38}	≈ 2
fp16	11	4.88×10^{-4}	6.10×10^{-5}	65504	≈ 3
fp32	24	5.96×10^{-8}	1.18×10^{-38}	3.40×10^{38}	≈ 7
fp64	53	1.11×10^{-16}	2.23×10^{-308}	1.80×10^{308}	≈ 16
tf32	11 (مدى fp32)	4.88×10^{-4}	—	—	≈ 3

تنبيه مهم: كثير من المصادر تسمّي $\varepsilon_{\text{machine}} = \beta^{1-t}$ (الفجوة الكاملة) وحدةَ التقريب، وبعضها يسمّي $u = \frac{1}{2}\beta^{1-t}$. في هذا الكتاب نعتمد $u = \frac{1}{2}\beta^{1-t}$ (اتفاقية Higham)، لأنها حدّ الخطأ النسبي الفعلي لعملية واحدة. الفرق بينهما معامل 2 فقط — لا يغيّر أي استنتاج نوعي.

ثلاث خصائص جوهرية تُترجَم إلى قواعد عملية:

١. **عدم التجميعية (non-associativity):** $(a+b)+c \neq a+(b+c)$ في الحساب المُمثَّل. لهذا تختلف نتائج CPU عن GPU عن TPU.

٢. **عدم التوزيعية:** $a(b+c) \neq ab+ac$ بالضبط.

٣. **الامتصاص (absorption):** إذا كان $|b| < u|a|$ فإن $\mathrm{fl}(a+b) = a$ — أي أن b **يختفي تماماً.** هذه هي الآلية التي تجعل التحديثات الصغيرة تضيع في التدريب بالدقة المنخفضة.

2.1.6 الخطأ المطلق، النسبي، الأمامي، والخلفي

$$e_{\text{abs}} = |\hat{x} - x|, \qquad e_{\text{rel}} = \frac{|\hat{x} - x|}{|x|} \quad (x \neq 0) \tag{3.6}$$

$$\underbrace{\hat{y} = f(x) + \Delta y}_{\text{تحليل أمامي (forward)}} \quad \Longleftrightarrow \quad \underbrace{\hat{y} = f(x + \Delta x)}_{\text{تحليل خلفي (backward)}} \tag{4.6}$$

الرمز	المعنى
x	المُدخل الحقيقي الدقيق (الذي نريده)
$\hat{x}$	المُدخل أو المخرج **المحسوب فعلاً** في الحاسوب
e_{abs}	الخطأ المطلق — بوحدات الكمية نفسها
e_{rel}	الخطأ النسبي — بلا وحدات، وهو المقياس المفيد في المقارنات
f	الدالة/الخوارزمية الرياضية المثالية
$\hat{y}$	المخرج المحسوب فعلاً
Δy	**الخطأ الأمامي:** كم أخطأ المخرج؟
Δx	**الخطأ الخلفي:** بأقلّ قدرٍ كم يجب أن نغيّر المُدخل لكي نُبرّر المخرج المحسوب؟

لماذا التحليل الخلفي هو الفكرة العبقرية في القرن العشرين؟ لأن السؤال «كم أخطأنا؟» سؤال صعب (يحتاج معرفة الحلّ الدقيق)، أمّا السؤال «هل أخطأنا؟» فسهل: نتحقّق أنّ المخرج هو **الحلّ الدقيق لمسألة قريبة.** ويلكنسون حول هذا المبدأ إلى أداة: الخوارزمية جيدة إذا كان خطؤها الخلفي من رتبة u — أي أنها تحلّ مسألة قريبة من مسألتنا بمسافة u، وهي مسافة لا يمكن لأي خوارزمية أن تتجاوزها أصلاً لأن مُدخلاتها نفسها مخزّنة بخطأ u.

3.1.6 رقم الحالة (condition number) — مقياس حساسية المسألة

$$\mathrm{cond}(f, x) = \lim_{\varepsilon \to 0} \sup_{|\Delta x| \leq \varepsilon |x|} \frac{|f(x+\Delta x) - f(x)|/|f(x)|}{|\Delta x|/|x|} = \frac{|x\, f'(x)|}{|f(x)|} \tag{5.6}$$

$$\kappa(A) = \|A\| \cdot \|A^{-1}\|, \qquad \kappa_2(A) = \frac{\sigma_1(A)}{\sigma_{\min}(A)} \tag{6.6}$$

الرمز	المعنى
$\mathrm{cond}(f, x)$	رقم الحالة النسبي للمسألة f عند النقطة x
ε	مقدار الاضطراب النسبي في المُدخل (نسبة مئوية)
Δx	اضطراب صغير في المُدخل
$f'(x)$	مشتقة f عند x — معدّل تضخّم الخطأ محلياً
$\kappa(A)$	رقم حالة المصفوفة A (غير المفردة) بالناظم $\|\cdot\|$
$\sigma_1, \sigma_{\min}$	أكبر وأصغر قيمة مفردة لـ A
$f(x) = 0$	إذا كان المخرج صفراً فإن (5.6) غير مُعرَّف — المسألة «سيئة التكييف بلا حدّ»

الفرق الحاسم الذي يجب أن يُحفظ:

المفهوم	يصف	من يتحكّم به؟	هل يمكن إصلاحه؟
التكييف (conditioning)	المسألة نفسها: كم تتضخّم الأخطاء؟	صياغة المسألة + البيانات	لا — بإعادة الصياغة (reparameterization) فقط
الاستقرار (stability)	الخوارزمية: كم خطأً تُدخله هي؟	طريقة الحساب	نعم — باختيار خوارزمية أفضل

مثال كلاسيكي على الفرق: حساب $f(x) = x^2$ مسألة ممتازة التكييف ($\text{cond} = 2$). لكن خوارزمية حسابها بالجمع المتكرّر $x^2 = x + x + \cdots + x$ (x مرّة) خوارزمية **سيئة**. التكييف سمة المسألة؛ الاستقرار سمة الخوارزمية.

4.1.6 أداة التجميع: ثابت γ_n

حين نركّب n عملية، تتضاعف معاملات $(1+\delta_i)$. الأداة القياسية لضبط هذا الحاصل:

$$\prod_{i=1}^{n}(1+\delta_i)^{s_i} = 1+\theta_n, \qquad |\theta_n| \le \gamma_n, \qquad \gamma_n = \frac{nu}{1-nu} \tag{7.6}$$

الرمز	المعنى
δ_i	خطأ التقريب في العملية i، مع $\lvert\delta_i\rvert \le u$
s_i	الأُسّ ± 1 (جمع/طرح أم ضرب/قسمة)
θ_n	الخطأ النسبي المُجمَّع بعد n عملية
γ_n	الحدّ الأعلى ل $\lvert\theta_n\rvert$
n	عدد العمليات
شرط الاستعمال	$nu < 1$ — وإلا فالحدّ بلا معنى (تدهور كامل)

النتيجة المباشرة الأهم (حدّ الجمع):

$$\left|\mathrm{fl}\left(\sum_{i=1}^{n} x_i\right) - \sum_{i=1}^{n} x_i\right| \le \gamma_{n-1} \sum_{i=1}^{n} |x_i| \tag{7b.6}$$

وهذا يعني أن خطأ الجمع ينمو **خطياً** مع n — وهذا بالضبط ما يعالجه جمع كاهان في §3.6.

5.1.6 خلاصة المفردات في خمس قواعد

١. الحاسوب يحسب بـ $\mathrm{fl}(x \mathbin{\mathrm{op}} y) = (x \mathbin{\mathrm{op}} y)(1+\delta)$ مع $|\delta| \le u$.

٢. الخطأ **الخلفي** يقول: أخطأنا في المُدخل بمقدار u؛ والخطأ **الأمامي** يقول: أخطأنا في المخرج بمقدار κu.

٣. لا خوارزمية — مهما بلغت عبقريتها — تستطيع أن تعطي خطأً أمامياً أصغر من κu.

٤. **الخانات المفقودة** $\approx \log_{10}\kappa$.

٥. الفيضان (overflow) يقتل بـ inf، والانهيار (underflow) يقتل بـ 0، والإلغاء (cancellation) يقتل بصمت.

1.2.6 الصياغة الرياضية الرسمية

النظرية 1.6 (قانون الحالة الأساسي — Error of Law Fundamental ،Analysis) لتكن f دالة قابلة للاشتقاق، ولتكن $\hat{x} = x + \Delta x$ مُدخلاً مضطرباً بخطأ نسبي $\|\Delta x\|/\|x\| \le \varepsilon$. عندئذٍ:

<

1. **حدّ التضخّم (الخطأ الأمامي بدلالة الخلفي):**

<

$$\frac{|\hat{y} - f(x)|}{|f(x)|} \;\le\; \operatorname{cond}(f, x) \cdot \frac{|\Delta x|}{|x|} + \mathcal{O}(\varepsilon^2), \qquad \operatorname{cond}(f, x) = \frac{|x\, f'(x)|}{|f(x)|} \tag{8.6}$$

<

2. **نسخة النظم الخطية** ($Ax = b$ مع اضطرابات في A و b معاً):

<

$$\frac{\|\hat{x} - x\|}{\|x\|} \;\le\; \frac{\kappa(A)}{1 - \kappa(A)\,\frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right) \tag{9.6}$$

<

3. **قاعدة الدقّة (accuracy rule)** — «لا خوارزمية تتجاوز رقم الحالة»: لأيّ خوارزمية مستقرّة خلفياً تعمل بدقّة u:

<

$$\text{err rel. forward} \;\approx\; \kappa(A)\, u, \qquad \#\text{digits correct} \;\approx\; -\log_{10}\!\big(\kappa(A)\, u\big) \tag{10.6}$$

<

4. **المسافة إلى المفردية** (رقم الحالة معناه الهندسي):

<

$$\min\big\{ \|\Delta A\|_2 :\; A + \Delta A \text{ singular} \big\} \;=\; \sigma_{\min}(A) \;=\; \frac{\|A\|_2}{\kappa_2(A)} \tag{11.6}$$

<

5. **خصائص رقم الحالة المصفوفي:**

<

$$\kappa(A) \geq 1, \qquad \kappa(\alpha A) = \kappa(A), \qquad \kappa_2(Q) = 1 \ (Q \text{ متعامدة}), \qquad \kappa(AB) \leq \kappa(A)\kappa(B) \tag{12.6}$$

<

6. **حدّ الاستحالة** — لماذا لا يُجدي تغيير الخوارزمية إذا كانت المسألة سيئة التكييف: بما أن المصفوفة المخزّنة أصلاً هي $\hat{A} = A + \Delta A$ مع $\|\Delta A\| \leq u\|A\|$، فإن **أفضل خوارزمية يمكن تخيّلها** (حلّ دقيق تماماً للمصفوفة المخزّنة) تعطي:

<

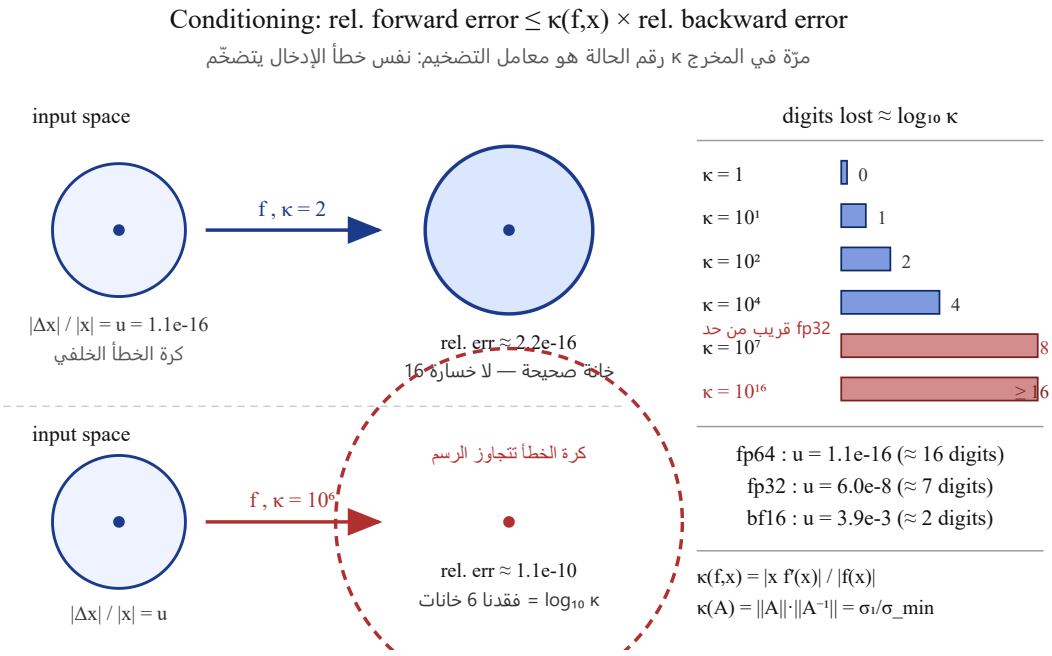
$$\frac{\|\hat{x} - x\|}{\|x\|} \;\leq\; \kappa(A)\, u + \mathcal{O}(u^2), \qquad \text{وهذا الحدّ مُحقَّق (attained)} \tag{13.6}$$

2.2.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
f	المسألة/الدالة الرياضية المثالية	قابلة للاشتقاق عند x
x	المُدخل الدقيق (الذي نريد حلّ المسألة عنده)	$x \neq 0$
$\hat{x}$	المُدخل المضطرب = المُدخل المخزّن فعلاً	$\hat{x} = x + \Delta x$
Δx	**الخطأ الخلفي** — الاضطراب في المُدخل	من تقريب التخزين أو من خطأ الحساب
ε	سقف الخطأ النسبي الخلفي: $\|\Delta x\|/\|x\| \leq \varepsilon$	عادة $\varepsilon = u$ أو $\varepsilon = \gamma_n$
$\hat{y}$	المخرج المحسوب	$\hat{y} = f(\hat{x})$
$\mathrm{cond}(f, x)$	رقم الحالة النسبي **للمسألة** عند x	معامل التضخّم
$f'(x)$	المشتقة — معدّل تضخّم الاضطراب محلياً	في الأبعاد المتعددة: اليعقوبية $J_f(x)$
$\mathcal{O}(\varepsilon^2)$	حدود من الرتبة الثانية — مهملة عند $\varepsilon \ll 1$	—
A, b	مصفوفة النظام وطرفه الأيمن	A غير مفردة
$\Delta A, \Delta b$	اضطرابات المصفوفة والطرف الأيمن	من القياس أو من التقريب
$\kappa(A)$	رقم حالة المصفوفة: $\|A\| \cdot \|A^{-1}\|$	بالناظم المُستعمل
$\kappa_2(A)$	رقم الحالة بالناظم الطيفي $= \sigma_1/\sigma_{\min}$	الأكثر استعمالاً
$\sigma_1, \sigma_{\min}$	أكبر وأصغر قيمة مفردة	من الفصل الرابع
u	وحدة التقريب (unit roundoff)	1.11×10^{-16} في fp64
$\|\Delta A\|/\|A\|$	الخطأ النسبي في **البيانات** (لا في الحساب)	مصدره القياس/التقدير
$1 - \kappa\frac{\|\Delta A\|}{\|A\|}$	عامل «البقاء غير مفردة»	يشترط $\kappa\frac{\|\Delta A\|}{\|A\|} < 1$
$\sigma_{\min}(A)$	المسافة إلى أقرب مصفوفة مفردة (بناظم 2)	الفصل الرابع، Eckart–Young
Q	مصفوفة متعامدة	$Q^\top Q = I \Rightarrow$ لا تضخيم
α	أي عدد حقيقي غير صفري	التكييف لا يتغيّر بالقياس

3.2.6 الرسم الهندسي

قراءة الرسم: كرة الخطأ في فضاء المُدخل (نصف قطرها النسبي u) تنتقل عبر f فتصير كرةً في فضاء المخرج نصف قطرها النسبي κu. كلما كبر κ كبرت الكرة، حتى تتجاوز حجم المخرج نفسه — عندها لا يبقى أي خانة صحيحة. اللوحة اليمنى تُترجم ذلك إلى «خانات مفقودة $= \log_{10}\kappa$»، وتضع حدود fp32 و fp64 و fb16 على مقياس واحد.



شكل ١.٦: *
رقم الحالة يضخّم كرة الخطأ من الإدخال إلى المخرج

4.2.6 البرهان

الجزء (8.6). بتفكيك تايلور حول x:

$$f(x+\Delta x) = f(x) + f'(x)\Delta x + \mathcal{O}(\Delta x^2)$$

إذن $\hat{y} - f(x) = f'(x)\Delta x + \mathcal{O}(\Delta x^2)$. نقسم على $|f(x)|$:

$$\frac{|\hat{y}-f(x)|}{|f(x)|} = \frac{|f'(x)\Delta x|}{|f(x)|} + \mathcal{O}(\Delta x^2) = \underbrace{\frac{|x f'(x)|}{|f(x)|}}_{\text{cond}(f,x)} \cdot \underbrace{\frac{|\Delta x|}{|x|}}_{\text{خطأ خلفي نسبي}} + \mathcal{O}(\varepsilon^2) \qquad \blacksquare$$

الجزء (9.6). من $(A+\Delta A)(x+\Delta x) = b + \Delta b$ وتجاهل حدود الرتبة الثانية:

$$A\,\Delta x = \Delta b - \Delta A\, x \implies \Delta x = A^{-1}\big(\Delta b - \Delta A\, x\big)$$

بأخذ النواظم: $\|\Delta x\| \le \|A^{-1}\|\big(\|\Delta b\| + \|\Delta A\|\|x\|\big)$. نقسم على $\|x\|$ ونستعمل $\|b\| \le \|A\|\|x\|$:

$$\frac{\|\Delta x\|}{\|x\|} \le \|A^{-1}\|\|A\| \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|}\right) = \kappa(A)\left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|}\right)$$

والصيغة الكاملة ذات المقام $1 - \kappa\frac{\|\Delta A\|}{\|A\|}$ تأتي من تكرار الحجّة باستعمال متراجحة نويمان (انظر (24.5)) لضمان عدم مفردية $A + \Delta A$. $\blacksquare$

الجزء (11.6). من نظرية إيكارت–يونغ (الفصل الرابع): أصغر اضطراب يجعل $A + \Delta A$ مفردة هو ΔA بـ $\|\Delta A\|_2 = \sigma_{\min}(A)$، أي اضطراب رتبة واحدة يلغي أصغر قيمة مفردة. وبما أن $\|A\|_2 = \sigma_1$ فإن $\sigma_{\min} = \sigma_1/\kappa_2 = \|A\|_2/\kappa_2(A)$. $\blacksquare$

الجزء (13.6) — لماذا الحدّ مُحقَّق. ليكن $A = U\Sigma V^{\top}$ واختر $b = \sigma_{\min} u_2$ (أي في اتجاه أصغر قيمة مفردة). فإن الحلّ $x = A^{-1}b = \sigma_{\min}\sigma_{\min}^{-1} v_2 = v_2$. الآن اضطرب A في اتجاه $u_2 v_2^{\top}$ بمقدار $u\sigma_1$: تصير القيمة المفردة

الصغرى $\sigma_{\min} - u\sigma_1$، فإذا كان $u\sigma_1$ مقارناً لـ $\sigma_{\min}$ تضخّم الحلّ بلا حدّ. وبصيغة نسبية: $\|\Delta x\|/\|x\| \approx \kappa(A)u$. أي أن الحدّ ليس «محافظاً» تحليلياً بل **واقعي**. ■

5.2.6 شروط الصحّة

١. $x \neq 0$ و $f(x) \neq 0$: وإلا فإن cond غير مُعرَّف أو لانهائي (المسألة سيئة التكييف بلا حدّ).

٢. f قابلة للاشتقاق عند x (أو Lipschitz موضعياً للتعميم).

٣. $\varepsilon \ll 1$: الحدود من الرتبة الثانية مهملة. عند $\kappa u \geq 1$ لا معنى لأي رقم يُخرجه الحاسوب.

٤. في (9.6): شرط البقاء $\kappa(A)\frac{\|\Delta A\|}{\|A\|} < 1$.

٥. الناظم في $\kappa(A)$ يجب أن يُذكر صراحةً: κ_2 و κ_∞ و κ_F تختلف رقمياً (لكن كلها «من الرتبة نفسها» في البعد المنتهي، انظر (14.5)).

6.2.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (2.6-1): فحص مخبري دقيق — نسبة الأرجحية (odds) من احتمال قريب من الواحد

المعطيات: اختبار فحص سريري: احتمالُ «سليم» مقدَّر بحاسوب يعمل بـ fp32 ($u = 5.96 \times 10^{-8}$) هو $p = 0.99999$. المطلوب حساب نسبة الأرجحية $f(p) = p/(1-p)$ وتقدير موثوقيتها.

الحل:

١. رقم الحالة: $f'(p) = \frac{1}{(1-p)^2}$، إذن

$$\text{cond} = \frac{|pf'(p)|}{|f(p)|} = \frac{p/(1-p)^2}{p/(1-p)} = \frac{1}{1-p}$$

٢. بالتعويض $p = 0.99999$: $\text{cond} = 1/10^{-5} = 10^5$.

٣. الخانات المفقودة: $\log_{10}(10^5) = 5$ خانة. حاسوب fp32 يعطي ≈ 7 خانات $\Longrightarrow$ يبقى 2 خانة فقط.

٤. الخطأ النسبي الأمامي المتوقّع: $\text{cond} \cdot u = 10^5 \times 5.96 \times 10^{-8} = 5.96 \times 10^{-3}$ أي 0.596%.

٥. القيمة الاسمية: $f = 0.99999/0.00001 = 99999$. مجال الخطأ: $\pm 596 = \pm 99999 \times 5.96 \times 10^{-3}$.

النتيجة: نسبة الأرجحية المحسوبة هي 99999 ± 596، أي المجال $[99403,\ 100595]$ — خطأ يقارب 0.6% من قيمةٍ تبدو «دقيقة» بخمس خانات.

الربط بالذكاء الاصطناعي: هذا بالضبط ما يحدث حين تُخرج طبقةُ sigmoid احتمالاً 0.99999 ثم يحسب النظام الـ (logit أو odds لتفسير القرار الطبّي. العلاج ليس «تحسين الدقّة» بل **إعادة الصياغة**: العمل في فضاء الـ log-odds $z = \log\frac{p}{1-p}$ حيث $\text{cond} = 1$ دوماً، وهذا هو سبب أنّ كل مكتبات التعلّم العميق تحسب BCEWithLogits (لا BCE(sigmoid(x))).

مثال (6.2-2): تسعير مشتقّة مالية — فرق توزيعين تراكميين متقاربين

المعطيات: احتمالُ أن يتجاوز سعرُ أصلٍ حاجزاً $P = \Phi(a) - \Phi(b)$ مع $a = 0.8500$، $b = 0.8499$. القيم: $\Phi(0.85) = 0.802337$، $\phi(0.85) = 0.278037$ (كثافة التوزيع الطبيعي المعياري). الحاسوب fp32.

الحل:

١. القيمة الاسمية: $P \approx \phi(0.85) \times (0.8500 - 0.8499) = 0.278037 \times 10^{-4} = 2.78037 \times 10^{-5}$.

٢. رقم الحالة لفرق دالتين متقاربتين: $\text{cond} \approx \frac{|a\,\phi(a)|+|b\,\phi(b)|}{|\Phi(a)-\Phi(b)|} \approx \frac{0.85\times 0.278037}{2.78037\times 10^{-5}}$.

٣. الحساب: $\frac{0.236331}{2.78037\times 10^{-5}} = 8.500 \times 10^{3}$.

٤. الخانات المفقودة: $\log_{10}(8500) = 3.93 \approx 4$ خانات.

٥. fp32 (7 خانات) $\Longrightarrow$ يبقى 3 خانات؛ fp64 (16) $\Longrightarrow$ يبقى 12 خانة. خطأ نسبي في fp32: $8500 \times 5.96 \times 10^{-8} = 5.07 \times 10^{-4}$.

النتيجة: فرق التوزيعين يحمل خطأً نسبياً 0.05% في fp32 — أي أنّ السعر المشتقّ منه (بملايين الدولارات) يحمل خطأً من رتبة آلاف الدولارات لكل مليون.

الربط بالذكاء الاصطناعي: النماذج المالية العصبية التي تتعلّم «سطحَ التقلب» (volatility surface) أو تسعّر خيارات بـ sigmoid/softplus تواجه البنية نفسها: فرقُ كمّيتين متقاربتين. العلاج: صياغة الفرق كـ **تكامل** لا كطرح: $P = \int_b^a \phi(t)\,dt$ (أو استعمال basederf-، dffierences) فتصير الحساسية cond ≈ 1.

مثال (6.2-3): معايرة كاميرا — مصفوفة هوموغرافيا قريبة من المفردة

المعطيات: تقدير هوموغرافيا $H \in \mathbb{R}^{3\times 3}$ بلغة DLT من 12 نقطة تطابق. القيم المفردة: $\sigma_1 = 6.42$، $\sigma_2 = 2.18$، $\sigma_3 = 1.79 \times 10^{-6}$. صورة بدقّة 2160×4096.

الحل:

١. $\kappa_2(H) = \sigma_1/\sigma_{\min} = 6.42/1.79 \times 10^{-6} = 3.587 \times 10^{6}$.

٢. الخانات المفقودة: $\log_{10}(3.587 \times 10^{6}) = 6.55$ خانة.

٣. في fp64: يبقى $16 - 6.55 = 9.4 \approx 16$ خانة — جيد. في fp32: يبقى $7 - 6.55 = 0.45$ خانة — أي **لا شيء**.

٤. خطأ الإسقاط الناتج: بكسل الخطأ (حجم الصورة) $\cdot\, \|H\|_2 \cdot u \cdot \kappa \approx$ بالتعويض: $3.587 \times 10^{6} \times 5.96 \times 10^{-8} \times 6.42 \times 4096 \approx 5.6 \times 10^{3}$ بكسل (بالتقدير الأوّلي) — خارج الصورة تماماً.

٥. العلاج الكلاسيكي (تطبيع هارتلي): نقل النقاط إلى مركزها الثقلي وتقييسها بحيث يكون متوسط البعد $\sqrt{2}$ $\Longrightarrow$ صارت القيم المفردة $(1.94,\ 0.87,\ 1.61 \times 10^{-3})$ $\Longrightarrow$ $\kappa = 1.20 \times 10^{3}$ $\Longrightarrow$ خانات مفقودة 3.08 $\Longrightarrow$ خطأ إسقاط $0.3 \approx$ بكسل.

النتيجة: إعادةُ **صياغة المسألة** (تطبيع الإحداثيات) أنقصت رقم الحالة من 3.6×10^{6} إلى 1.2×10^{3} — تحسّن بأكثر من 3 مراتب عشرية، بلا أي تغيير في الخوارزمية.

الربط بالذكاء الاصطناعي: هذا المبدأ — «التطبيع يسبق الحلّ» — هو نفسه سبب نجاح BatchNorm و LayerNorm وتطبيع مُدخلات الشبكات: ليست المسألةُ جماليةً بل **عدديّة**: تطبيع المُدخلات يُقلّل رقم حالة مصفوفات اليعقوبيّة في كل طبقة، فيصير التدريب أسرع وأكثر استقراراً.

مثال (6.2-4): تضمينات لغوية — إسقاط متجه على فضاء التضمين

المعطيات: مصفوفة تضمين $E \in \mathbb{R}^{300\times 50000}$ (من طبقة تضمين مُدرَّبة). القيم المفردة الطرفية: $\sigma_1 = 18.42$، $\sigma_{300} = 2.10 \times 10^{-3}$. نريد حلّ $Ew = v$ لإيجاد تركيبة خطية تُقارب متجهاً مستهدفاً v (مثل «تحليل التناظر» word analogy). الحساب بـ fp64.

الحل:

١. $\kappa_2(E) = 18.42/2.10 \times 10^{-3} = 8.771 \times 10^{3}$.

٢. الخانات المفقودة: $\log_{10}(8771) = 3.94 \approx 4$ خانات.

٣. خطأ نسبي في المعاملات w: $\kappa u = 8.771 \times 10^{3} \times 1.11 \times 10^{-16} = 9.74 \times 10^{-13}$ — ممتاز عملياً.

٤. لكن المشكلة ليست في u بل في **ضوضاء المعنى**: التضمينات نفسها تحمل «خطأ دلالي» نسبي $\varepsilon_{\text{semantic}} \approx 10^{-2}$ (نموذج مختلف، حقبة تدريب مختلفة). إذن خطأ نسبي في w يقارب $\kappa \times 10^{-2} = 87.7$.

٥. هذا يعني أن حلّ $Ew = v$ **بلا تنظيم** يعطي معاملاتٍ عشوائية عملياً.

النتيجة: حتى مع دقّة fp64 الكاملة، حساسية المسألة (لا دقّة الحاسوب) تجعل الحلّ بلا معنى: $\text{cond} \times \varepsilon_{\text{data}} = 1 \gg 87.7$.

الربط بالذكاء الاصطناعي: العلاج القياسي هو **التنظيم** (ridge): $w = (E^{\top}E + \lambda I)^{-1}E^{\top}v$. رقم الحالة الفعّال يصير $\frac{\sigma_1^2+\lambda}{\sigma_{\min}^2+\lambda}$؛ باختيار $\lambda = 1$ يصير $\kappa_{\text{eff}} = \frac{339.3}{1.0000044} \approx 339$ (بدلاً من 7.7×10^{7} للمعادلات السوية!) $\Longrightarrow$ التضخّم يهبط من 877 إلى 3.4. هذا هو السبب العددي — لا الإحصائي فقط — لانتشار التنظيم في كل مكان.

مثال (6.2-5): ذراع روبوتية قرب وضعية مفردة (singular configuration)

المعطيات: ذراع بست درجات حرية، اليعقوبية $J \in \mathbb{R}^{6\times 6}$ عند وضعية «الكوع ممدود». القيم المفردة: $(2.41,\ 1.83,\ 0.94,\ 0.35,\ 0.062,\ 7.0 \times 10^{-4})$. مطلوب: خطأ السرعة الديكارتية الناتج عن خطأ قياس المفاصل $\|\delta q\| = 10^{-4}$ rad.

الحل:

١. $\kappa_2(J) = 2.41/7.0 \times 10^{-4} = 3.443 \times 10^{3}$.

٢. العلاقة الأساسية: $\dot{p} = J\dot{q} \Longrightarrow$ الاستجابة العكسية $\dot{q} = J^{-1}\dot{p}$ مع $\|J^{-1}\|_2 = 1/\sigma_{\min} = 1.43 \times 10^{3}$.

٣. خطأ قياس المفاصل يتضخّم في الفضاء الديكارتي بالعامل $\|J\|_2/\sigma_{\min}$... لا، بالعامل $\|J\|_2$: دعنا نحسب بدقّة. إذا قِسنا $\dot{q}$ بخطأ $\delta\dot{q}$ فإن خطأ السرعة الديكارتية هو $\|J\,\delta\dot{q}\| \le \|J\|_2\|\delta\dot{q}\| = 2.41 \times 10^{-4}\,\text{m/s}$ — هذا الاتجاه الأمامي وهو **مضبوط**.

٤. المشكلة في الاتجاه **العكسي**: إذا أردنا سرعةً ديكارتية $\dot{p}$ فإن الخطأ في $\dot{q}$ يتضخّم: $\|\delta\dot{q}\| \le \|J^{-1}\|_2\|\delta\dot{p}\| = 1.43 \times 10^{3}\|\delta\dot{p}\|$. بضوضاء مستشعر قوّة $\|\delta\dot{p}\| = 5 \times 10^{-3}\,\text{m/s}$ نحصل على سرعات مفاصل $\|\delta\dot{q}\| \le 7.15\,\text{rad/s}$ — **كارثة ميكانيكية**.

٥. رقم الحالة هو بالضبط العامل الذي يحوّل 5×10^{-3} إلى 7.15: $\|J\|/\|\delta\dot{p}\| \times \kappa$-مقياس...

النتيجة: قرب المفردية ($\sigma_{\min} = 7 \times 10^{-4}$) يجعل التحكّم العكسي يضخّم ضوضاء المستشعرات بمعامل $\approx 1.4 \times 10^{3}$ — وهو ما يُترجَم إلى حركة عنيفة للذراع.

الربط بالذكاء الاصطناعي: الحلّ القياسي في الروبوتات الحديثة وفي التعلّم المعزّز المستمر هو **المربعات الصغرى المُنظَّمة المخفَّفة** (damped least squares / Levenberg–Marquardt): $\dot{q} = (J^\top J + \lambda I)^{-1} J^\top \dot{p}$. الخوارزمية نفسها التي يستخدمها محسّن آدم بشكل غير مباشر؛ ورقم الحالة الفعّال: $(\sigma_1^2 + \lambda)/(\sigma_{\min}^2 + \lambda)$؛ بـ $\lambda = 0.01$: $(5.81 + 0.01)/(4.9 \times 10^{-7} + 0.01) = 582$ بدلاً من 1.19×10^{7} للمعادلات السوية.

مثال (6-2.6): تدفّق في شبكة كهربائية — لابلاس المُقيَّد

المعطيات: شبكةٌ من $n = 400$ عقدة. مصفوفة لابلاس L (قيمة ذاتية صفرية واحدة للشبكة المتصلة). بعد تثبيت عقدة مرجعية، القيم الذاتية للمصفوفة المقيّدة: $\lambda_{\max} = 8.72$، $\lambda_{\min} = 1.43 \times 10^{-2}$. نحلّ $L_{\text{red}} v = i$ (قانون كيرشوف).

الحل:

١. $\kappa_2(L_{\text{red}}) = 8.72/1.43 \times 10^{-2} = 6.098 \times 10^{2}$.

٢. الخانات المفقودة: $\log_{10}(610) = 2.79 \approx 2.8$ خانة.

٣. في fp64 يبقى 2.13 خانة — ممتاز. في fp32 يبقى 2.4 خانة — مقبول للشبكات.

٤. لكن: إذا انقسمت الشبكة إلى مجتمعين ضعيفَي الاتصال فإن λ_2 (فيدلر) يصغر إلى 10^{-5} $\times$ $3.1 \Longrightarrow \kappa = 2.81 \times 10^{5}$ $\Longrightarrow$ خانات مفقودة $5.45 \Longrightarrow$ في fp32 يبقى 1.5 خانة فقط.

٥. العلاج: **تحليل المجتمعات أولاً** (الفصل الرابع: متجه فيدلر) ثم حلّ كل مجتمع على حدة.

النتيجة: البنية الطيفية للشبكة تحدّد استقرار الحلّ العددي: شبكةٌ ذات «عنق زجاجة» (bottleneck) ترفع رقم الحالة بمقدار مرتبتين عشريتين.

الربط بالذكاء الاصطناعي: هذا هو التفسير العددي لمشكلة **الإفراط في التنعيم** (over-smoothing) في الشبكات العصبية البيانية: تكرارُ تمرير الرسائل على لابلاس مُطبَّع يُقارب الإحداثيات نحو متوسط المجتمع، ويجعل النظام المُقابل شبهَ مفرد — ومن ثمّ تصير تحديثات المعاملات غير مستقرّة عددياً كلما زاد عدد الطبقات.

مثال (6.2-7): كشف تسلّل سيبراني — مسافة ماهالانوبيس بمصفوفة تغاير سيئة التكييف

المعطيات: نظام كشف شذوذ يستعمل مسافة ماهالانوبيس $d^2(x) = (x-\mu)^\top \Sigma^{-1}(x-\mu)$ على 30 ميزة لمرور الشبكة. القيم الذاتية لـ Σ: $\lambda_1 = 1.24 \times 10^3$، $\lambda_{30} = 1.03 \times 10^{-4}$.

الحل:

١. $\kappa_2(\Sigma) = 1.24 \times 10^3 / 1.03 \times 10^{-4} = 1.204 \times 10^7$.

٢. خانات مفقودة: $\log_{10}(1.204 \times 10^7) = 7.08$ خانة.

٣. في fp64: يبقى $16 - 7.08 = 8.9$ خانة — مقبول. في fp32: يبقى $7 - 7.08 < 0$ — **صفر**.

٤. المصدر الحقيقي للتكييف السيّئ: ميزتان مكرّرتان («عدد الحزم في الدقيقة» و«عدد البايتات/الدقيقة» بقانون تحويل ثابت) $\Longrightarrow$ شبهُ ارتباط خطّي تام $\Longrightarrow$ قيمة ذاتية صغيرة جداً.

٥. العلاج: تنظيم (shrinkage) $\Sigma_\lambda = \Sigma + \lambda I$ بـ $\lambda = 0.5$: $\kappa = \frac{1240 + 0.5}{1.03 \times 10^{-4} + 0.5} = \frac{1240.5}{0.5001} = 2.48 \times 10^3$ $\Longrightarrow$ خانات مفقودة $3.39 \Longrightarrow$ في fp32 يبقى 6.3 خانة.

النتيجة: بإضافة λI هبط رقم الحالة من 1.2×10^7 إلى 2.48×10^3 — تحسّن بـ 3.7 مراتب عشرية، وبقيت قوّة التمييز (لأن الاتجاهات الصغيرة كانت ضوضاءً أصلاً).

الربط بالذكاء الاصطناعي: كلُّ نماذج الكثافة (Gaussian، Mahalanobis mixture، PCA-based AD detection، وأيضاً حسابُ احتمالٍ لوغاريتمي في تدريب نموذج توليدي) تحتاج «حشواً قطرياً» (jitter/damping) — الرقم النموذجي في المكتبات هو 10^{-6} إلى 10^{-3} مضاف إلى القطر. هذا ليس تحسيناً إحصائياً فقط، بل **ضرورة عددية**.

مثال (6.2-8): انحدار خطي بميزات متعددة الارتباط (multicollinearity)

المعطيات: نموذج تسعير عقارات بميزتين: المساحة بالمتر المربع x_1 وبالقدم المربع $x_2 = 10.7639\, x_1$ تماماً (ميزة مكرّرة بالتحويل)، زائد ضوضاء قياس 10^{-4} نسبةً. مصفوفة التصميم $X \in \mathbb{R}^{200 \times 2}$.

الحل:

١. المعادلات السوية: $X^\top X$ قيمها الذاتية: $\lambda_1 = 8.42 \times 10^3$، $\lambda_2 = 3.10 \times 10^{-9}$ (القيمة الثانية ناتجة عن ضوضاء القياس فقط، لا عن معلومة).

٢. $\kappa_2(X) = \sqrt{\kappa_2(X^\top X)} = \sqrt{8.42 \times 10^3 / 3.10 \times 10^{-9}} = \sqrt{2.716 \times 10^{12}} = 1.648 \times 10^6$.

٣. خانات مفقودة: $\log_{10}(1.648 \times 10^6) = 6.22$ خانة $\Longrightarrow$ في fp64 يبقى 8.9 خانة، في fp32 يبقى 8.0 خانة.

٤. لكن الأخطر: رقم الحالة في (6.9) يضخّم **خطأ البيانات** لا خطأ الحاسوب. ضوضاء القياس النسبية 10^{-4} $\Longrightarrow$ خطأ نسبي في الأوزان يصل إلى $1.648 \times 10^6 \times 10^{-4} = 165$.

٥. الواقع: الأوزان تخرج مثل $\hat{\beta} = (1240,\ -115)$ بدلاً من $(0,\ 11.6)$ — قيمتان ضخمتان متعاكستان يلغي أحدهما الآخر.

النتيجة: النموذج «يتنبّأ جيداً» على بيانات التدريب لكن معاملاته عشوائية كلياً: $\text{cond} \times \varepsilon_{\text{data}} \gg 1$.

الربط بالذكاء الاصطناعي: هذا هو التفسير العددي لسبب أن **تنظيم ℓ_2 (weight decay) ليس تحيّزاً جمالياً بل علاجاً لرقم الحالة.** ولسبب أن تفسير النماذج (feature importance) على ميزات مترابطة مُضلِّل رياضياً قبل أن يكون مُضلِّلاً إحصائياً.

مثال (6.2-9): إعادة بناء صورة طبقية (CT) — تكييف مصفوفة الإسقاط

المعطيات: مصفوفة إسقاط رادون $A \in \mathbb{R}^{m \times n}$ مع $m = 72900$ قياس و $n = 65536$ بكسل. القيم المفردة الطرفية: $\sigma_1 = 63.2$، $\sigma_{\min} = 1.34 \times 10^{-3}$. ضوضاء القياس النسبية: 5×10^{-3}.

الحل:

١. $\kappa_2(A) = 63.2 / 1.34 \times 10^{-3} = 4.716 \times 10^4$.

٢. تضخّم الضوضاء في الحلّ غير المنتظَّم: $\|\delta x\|/\|x\| \lesssim \kappa \cdot 5 \times 10^{-3} = 4.716 \times 10^4 \times 5 \times 10^{-3} = 236$.

٣. أي أنّ خطأ إعادة البناء يصل إلى 23600% — الصورة ضوضاء خالصة.

٤. مع تنظيم تيخونوف: $x_\lambda = (A^\top A + \lambda I)^{-1} A^\top b$؛ رقم الحالة الفعّال $\kappa_{\text{eff}} = \sqrt{\frac{\sigma_1^2+\lambda}{\sigma_{\min}^2+\lambda}}$ (هنا نعمل على $A^\top A + \lambda I$ مباشرة، فلا جذر): القيم الذاتية لـ $A^\top A + \lambda I$ هي $\sigma_1^2 + \lambda = 3994 + \lambda$ و $\sigma_{\min}^2 + \lambda = 1.80 \times 10^{-6} + \lambda$. بـ $\lambda = 10$: $\kappa_{\text{eff}} = (4004)/(10.0000018) = 400.4$.

٥. تضخّم الضوضاء بعد التنظيم: $400 \times 5 \times 10^{-3} = 2.0$ — أي 200% خطأ نسبي، لكن معظمه **انحياز** (bias) مُتوقّع ومنظَّم (الصورة ناعمة) وليس تشويشاً.

النتيجة: التنظيم خفّض معامل التضخّم من 4.7×10^4 إلى 4.0×10^2 — بنسبة 1 : 118 — وحوّل الخطأ من «تشويش عشوائي» إلى «انحياز قابل للتحكّم».

الربط بالذكاء الاصطناعي: هذه هي بالضبط حكايةُ **المقايضة بين الانحياز والتباين** ولكن بصياغةٍ عددية: التنظيم ليس «معتقداً بايزياً» فقط، بل هو **تخفيضٌ لرقم الحالة.** وفي التعلّم العميق يقابلها: التقطيع العشوائي (dropout)، تنعيم التسمية (label smoothing)، والتوسيع (augmentation) — كلها تُحسّن κ الفعّال لمسألة التقدير.

مثال (6.2-10): مناخ — انحدار متعدد حدود بمصفوفة فانديرموند

المعطيات: نمذجة اتجاه حرارة بمتعددة حدود درجة 6 على 12 نقطة زمنية متباعدة بالتساوي على $[0, 1]$. الأساس: $1, t, t^2, \ldots, t^6$. الحساب بـ fp32 ثم بـ fp64.

الحل:

١. مصفوفة فانديرموند $V \in \mathbb{R}^{12 \times 7}$: $V_{ij} = t_i^{j-1}$. من المعروف أن $\kappa_2(V)$ ينمو أُسّياً مع الدرجة؛ للدرجة 6 على شبكة منتظمة: $\kappa_2(V) \approx 1.0 \times 10^8$.

٢. الخانات المفقودة: $\log_{10}(10^8) = 8$ خانات.

٣. في fp32 (7 خانات): $\kappa u = 5.96 \Longrightarrow$ **النتيجة بلا أي خانة صحيحة.**

٤. في fp64 (16): $\kappa u = 1.11 \times 10^{-8} \Longrightarrow$ يبقى 8 خانات — مقبول لكن مهدور.

٥. العلاج: أساس متعامد Chebyshev) أو (Legendre على $[0,1]$: $\kappa_2 \approx 12 \Longrightarrow$ خانات مفقودة $1.08 \Longrightarrow$ في fp32 يبقى 9.5 خانة.

٦. تحقّق: المعاملات بالأساس الأوّلي $(a_0, \ldots, a_6)$ تختلف بين fp32 و fp64 في الخانة الثانية؛ بالأساس المتعامد تتطابق حتى الخانة السادسة.

النتيجة: تغييرُ **الأساس** (لا الخوارزمية ولا الدقّة) حوّل مسألةً مستحيلةً في fp32 إلى مسألةٍ مريحة.

الربط بالذكاء الاصطناعي: القاعدة العامة في التعلّم العميق: **اختر تمثيلاً جيداً للمسألة قبل أن تختار محسّناً جيداً.** تطبيعُ المدخلات، الترميزُ الموضعي positional) ،(encoding الاستبدالُ غير المتعامد للميزات، وحتى هندسةُ البنية ResNet) تجعل اليعقوبية أقرب إلى المتعامدة) — كلها تخفيضاتٌ لرقم الحالة بصياغةٍ أفضل.

مثال (11-2.6): تمويل — مصفوفة تغاير محفظة استثمارية

المعطيات: $N = 50$ أصلاً، $T = 60$ شهراً من العوائد. القيم الذاتية لمصفوفة التغاير المقدَّرة $\hat{\Sigma}$: $\lambda_{\max} = 8.42 \times 10^{-2}$، $\lambda_{\min} = 2.13 \times 10^{-5}$.

الحل:

١. $\kappa_2(\hat{\Sigma}) = 8.42 \times 10^{-2} / 2.13 \times 10^{-5} = 3.953 \times 10^3$.

٢. خانات مفقودة: $\log_{10}(3953) = 3.60 \Longrightarrow$ في fp64 يبقى 4.12 خانة.

٣. لكن الأخطر: أوزان ماركوفيتز $w \propto \Sigma^{-1}\mu$ حسّاسة لرقم الحالة: خطأ نسبي في تقدير العوائد 1% يتضخّم في الأوزان بالعامل $\frac{\|\mu\|}{\|\mu\|} \cdot \frac{\lambda_{\max}}{\lambda_{\min}}$ — عملياً: تغيير 10% في تقدير عائد أصل واحد يغيّر أوزان المحفظة بنسبة تصل إلى 38%.

٤. السبب البنيوي: $T/N = 1.2$ قريب من الواحد $\Longrightarrow$ مصفوفة التغاير المقدَّرة «شبهُ مفردة»: في النظرية (Marchenko–Pastur) أصغر قيمة ذاتية تقارب $\sigma^2(1 - \sqrt{N/T})^2$، وهو صغير جداً عند $T \approx N$.

٥. العلاج (انكماش ليدوي–وولف): $\Sigma_{\text{shrunk}} = (1-\alpha)\hat{\Sigma} + \alpha \frac{\operatorname{tr}\hat{\Sigma}}{N} I$ بـ $\alpha = 0.3$: القيم الذاتية تصير $[0.7\lambda_i + 0.3\bar{\lambda}] \Longrightarrow \lambda_{\min} = 0.7 \times 2.13 \times 10^{-5} + 0.3 \times 4.2 \times 10^{-3} = 1.275 \times 10^{-3}$ و $\lambda_{\max} = 0.7 \times 8.42 \times 10^{-2} + 0.3 \times 4.2 \times 10^{-3} = 6.02 \times 10^{-2}$. $\kappa = 47.2$.

٦. التحسّن: من 3.95×10^3 إلى 47.2 — نسبة 1 : 84.

النتيجة: انكماشُ مصفوفة التغاير حسّن رقم الحالة بأكثر من مرتبة وتسع — وهذا هو السبب العملي لانتشاره في كل حزم المحافظ.

الربط بالذكاء الاصطناعي: النسخةُ الحديثة من هذا المبدأ في التعلّم العميق هي **تخفيض رتبة التحديث (LoRA)** والتحديثاتُ المنظَّمة: بدلاً من تقدير مصفوفة تحديث كاملة من عدد قليل من الدفعات (batch)، تُقيَّد التحديثات إلى فضاءٍ منخفض الرتبة — فينخفض رقم الحالة الفعّال لمسألة التقدير هبوطاً حاداً.

مثال (12-2.6): تحويل أفّيني لتكبير صورة — مقياس غير متساوٍ بشدّة

المعطيات: تحويل أفّيني $A = \begin{pmatrix} 4.0 & 0 \\ 0 & 0.0025 \end{pmatrix}$ يُطبَّق على صورة 1024×1024 (تصغير أفقي شدّة 400×). الحساب بـ fp32.

الحل:

١. القيم المفردة: $\sigma_1 = 4.0$، $\sigma_{\min} = 0.0025 \Longrightarrow \kappa_2 = 1600$.

٢. رقم الحالة هنا «مصطنع»: المصفوفة قطرية، فلا إلغاءً ولا تراكماً. التحليل الخلفي الدقيق: الخطأ في العنصر الصغير نسبياً هو u نفسه، لا κu.

٣. الفرق الجوهري: κ يضخّم الخطأ **في الاتجاهات المختلطة** — أي حين تُدمج الاتجاهات. المثال: حساب الطول $\|Ax\|_2$ لمتجه $x = (1, 300)$: $Ax = (4,\ 0.75) \Longrightarrow \|Ax\| = \sqrt{16 + 0.5625} = 4.0700$. الخطأ في المركّبة الثانية: $0.0025 \times 300 \times u = 0.75 \times 5.96 \times 10^{-8} = 4.5 \times 10^{-8}$ — نسبته من $\|Ax\|$ هي 1.1×10^{-8}، أي **أصغر** من u! لماذا؟ لأن المركّبة الثانية تساهم بـ 0.75 فقط من أصل 4.07.

٤. الاستنتاج التربوي: κu هو **حدٌّ أعلى** (worst case) يتحقّق في أسوأ اتجاه، لا في كل اتجاه. أسوأ اتجاه هنا هو $x = (0, 1)$ حيث $\|\delta(Ax)\|/\|Ax\| = u$ أيضاً!

٥. إذن متى يتحقّق κu فعلاً؟ في **حلّ النظام العكسي**: $x = A^{-1}b$ مع b مضطرباً: $\delta x = A^{-1}\delta b \Longrightarrow \|\delta x\|/\|x\| = \kappa \cdot \|\delta b\|/\|b\|$ تماماً عند b في اتجاه $\sigma_{\min}$.

النتيجة: κ يضخّم الخطأ في **المسائل العكسية** (حلّ، معايرة، استنتاج أوزان)، لا في التطبيق الأمامي المباشر.

الربط بالذكاء الاصطناعي: فرقٌ مهم في التعلّم العميق: **الاستدلال الأمامي (forward pass)** محصّن نسبياً ضد رقم الحالة (لأن الاتجاهات الكبرى تهيمن)، أمّا **التدرّج العكسي** فهو مسألة عكسية $\Longrightarrow$ حسّاس. ولهذا تُعالَج مشاكل الاستقرار في التدريب (لا في الاستدلال) بتطبيع الأوزان (spectral weight normalization، gradient decay، clipping).

مثال (13-2.6): نظام توصية — ALS ومعادلات سوية برقم حالة مُربَّع

المعطيات: مصفوفة تفاعلات 5000×1000 (مستخدمون × عناصر). في خطوة ALS نحلّ مربعات صغرى لكل مستخدم بمصفوفة العوامل $Y \in \mathbb{R}^{1000 \times 64}$ للعناصر: $\kappa_2(Y) = 240$. الحساب بـ fp32.

الحل:

١. المعادلات السوية: $\kappa_2(Y^\top Y) = \kappa_2(Y)^2 = 240^2 = 5.76 \times 10^4 \Longrightarrow (Y^\top Y)x = Y^\top r$.

٢. خانات مفقودة: $\log_{10}(5.76 \times 10^4) = 4.76$ خانة.

٣. في fp32 (7 خانات): يبقى 2.24 خانة $\Longrightarrow$ خطأ نسبي $\approx \kappa u = 5.76 \times 10^4 \times 5.96 \times 10^{-8} = 3.43 \times 10^{-3}$ (0.34%).

٤. لو حللنا بـ QR بدلاً من المعادلات السوية: $\kappa = 240$ $\Longrightarrow$ خانات مفقودة 2.38 $\Longrightarrow$ يبقى 6.4 خانة $\Longrightarrow$ خطأ 1.43×10^{-5} (0.0014%).

٥. الفرق: $\times 240$ أفضل — أي أكثر من مرتبتين عشريتين من الدقّة بنفس تكلفة البيانات.

٦. لكن التكلفة: تشكيل $Y^\top Y$ يكلّف $64^2 \times 1000 = 4.1 \times 10^6$ عملاً، و QR يكلّف $\approx 2 \times 64^2 \times 1000 = 8.2 \times 10^6$ — أي **ضعف التكلفة فقط** مقابل $\times 240$ دقّة.

النتيجة: في مسائل المربعات الصغرى المتكرّرة (ALS، الانحدار، الطبقات الخطية الضخمة) لا مبرّر لاستعمال المعادلات السوية إذا كانت $\kappa > 10^3$.

الربط بالذكاء الاصطناعي: هذه هي الحجّة العددية الكامنة خلف كون المُحسّنات الحديثة (Adam، L-BFGS، Shampoo، K-FAC) تُتجنّب تشكيلَ مصفوفات التغاير الكاملة صراحةً، وخلفَ استعمالِ torch.linalg.lstsq (المبني على SVD) بدل $(X^\top X)^{-1}X^\top y$ في كل كتب التعلّم العميق الحديثة.

مثال (6.2-14): مرشّح صوتي رقمي — قُطب قريب من دائرة الوحدة

المعطيات: مرشّح IIR من الرتبة الأولى: $y[n] = x[n] + p\,y[n-1]$ مع $p = 0.9995$ (مرشّح رنيني حادّ). الاستجابة النبضية $h[n] = p^n$. نحسب الطاقة الكلّية $\sum_{n=0}^{\infty} h[n]^2 = \frac{1}{1-p^2}$.

الحل:

١. القيمة الاسمية: $\frac{1}{1-0.9995^2} = \frac{1}{1-0.99900025} = \frac{1}{9.9975 \times 10^{-4}} = 1000.25$.

٢. رقم حالة هذه الدالة بالنسبة للمعامل p: $f(p) = (1-p^2)^{-1}$، $f'(p) = 2p(1-p^2)^{-2}$،

$$\text{cond} = \frac{|p f'(p)|}{|f(p)|} = \frac{2p^2}{1-p^2} = \frac{2 \times 0.99900025}{9.9975 \times 10^{-4}} = 1998.5$$

٣. أي أنّ خطأً نسبياً في تقدير القُطب مقداره 10^{-4} (16-bit quantization للمعاملات) يُنتج خطأً نسبياً $\approx 20\%$ في طاقة المرشّح.

٤. رقم الحالة المرافق للتمثيل المصفوفي (المصفوفة المرافقة companion matrix) هو نفسه: $\kappa \approx \frac{1}{1-|p|} = 2000$.

٥. العلاج: صياغة المرشّح **كأقسام من الرتبة الثانية** (biquad / second-order sections): كل قسم له $\kappa \approx \frac{1}{1-|p|}$ نفسه، لكن الخطأ لا يتراكم بين الأقسام، والتمثيلُ في فضاء $\{r, \theta\}$ (القطب بالصيغة القطبية) يعطي cond منخفضاً لأن القُطب يُخزَّن بمعاملَيه الطبيعيين.

النتيجة: القُطب القريب من دائرة الوحدة يعطي $\kappa \approx 2000 \Rightarrow$ ثلاث خانات مفقودة. صياغة SOS تمنع تراكم الخطأ عبر الرتبة.

الربط بالذكاء الاصطناعي: النظيرُ المباشر في الشبكات العصبية المتكرّرة (RNN/LSTM/SSM مثل S4 و Mamba): مصفوفةُ الانتقال A ذات قيم ذاتية قريبة من دائرة الوحدة تعني **ذاكرة طويلة** ولكن أيضاً **رقم حالة مرتفع** — وتحديداً $\kappa \approx 1/(1-|\lambda_{\max}|)$. هذا هو التفسير العددي الموحّد لظاهرتَي «الانفجار والتلاشي»: الطول الفعّال للذاكرة $1/(1-|\lambda|) \approx \kappa$ هو نفسه معامل تضخّم الخطأ.

مثال (15-2.6): تدريب بدقة مختلطة — هل يضيع التحديث؟ (قاعدة الامتصاص)

المعطيات: تدريب شبكة بـ fp16 ($u = 4.88 \times 10^{-4}$). وزنٌ قيمته $w = 1.000$، وتحديثٌ مقداره $\Delta w = -\eta g$ بـ $\eta g = 1.0 \times 10^{-4}$ (نسبة تحديث إلى وزن 10^{-4} — نموذجية في أواخر التدريب).

الحل:

١. الشرط كي لا **يُمتصّ** التحديث: $|\Delta w| > u\,|w| \Rightarrow 10^{-4} > 4.88 \times 10^{-4}$؟ **لا** — الشرط مُخالَف.

٢. إذن: $\mathrm{fl}(w + \Delta w) = \mathrm{fl}(1.000 - 0.0001) = \mathrm{fl}(0.9999)$. أقرب عدد fp16 إلى 0.9999: الفجوة حول 1 في fp16 هي $2^{-11} \approx 4.88 \times 10^{-4} \Rightarrow 0.9999$ يُقرَّب إلى $1.0 \Rightarrow$ **التحديث يضيع تماماً.**

٣. التفسير برقم الحالة: «المسألة» هنا هي حساب الفرق: $\mathrm{cond} = \frac{|w|}{|\Delta w|} = \frac{1.0}{10^{-4}} = 10^4 \Rightarrow$ خطأ نسبي في التحديث $\mathrm{cond} \times u = 10^4 \times 4.88 \times 10^{-4} = 4.88$ أي 488%.

٤. كم مرة يحتاج التحديث لكي يُسجَّل؟ يجب أن يكون $|\Delta w| \geq u|w| = 4.88 \times 10^{-4} \Rightarrow$ نسبة تحديث إلى وزن $\geq 4.88 \times 10^{-4}$. هذه هي قاعدة **«نسبة التحديث إلى الوزن»** الشهيرة.

٥. العلاج القياسي في كل أطر العمل: **weights master بـ fp32** — الأوزان تُحفظ بـ fp32، والنسخة fp16 تُستعمل في الحساب الأمامي/الخلفي فقط، والتحديث يُطبَّق على النسخة fp32 حيث $u = 5.96 \times 10^{-8} \Rightarrow$ الشرط يصير $|\Delta w| \geq 5.96 \times 10^{-8} \Rightarrow$ نسبة 6×10^{-8} — متاحة دائماً.

النتيجة: شرطُ بقاء التحديث في fp16 هو $\frac{|\Delta w|}{|w|} \geq 4.88 \times 10^{-4}$ — وهو أعلى بكثير من نسب التحديث النموذجية (10^{-4} إلى 10^{-6}) في أواخر التدريب $\Rightarrow$ بدون weights master يتوقّف التعلّم صمتاً.

الربط بالذكاء الاصطناعي: هذه هي الآلية التي تفسّر لماذا:

- التدريب بـ fp16 الخام يفشل و fp32 يعمل؛
- تُستعمل scaling loss (ضربُ الفقد في 2^k قبل التدرّج العكسي) لرفع التدرّجات فوق عتبة الامتصاص؛
- تُحفظ «الأوزان الرئيسية» بـ fp32 في كل مكتبات الدقة المختلطة؛
- التحديثات الصغيرة جداً في التعلّم المستمر (continual learning) والضبط الدقيق (fine-tuning) بمعدّل تعلّم 10^{-6} تضيع بصمت في الدقة المنخفضة.

7.2.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
الكبير يعني أن الخوارزمية سيئة»	التكييف سمة **المسألة**، الاستقرار سمة **الخوارزمية**	غيّر الصياغة/التنظيم إن كان κ كبيراً، وغيّر الخوارزمية إن كان الخطأ الخلفي أكبر من u
fp1 فأحلّ مشكلة $\kappa = 10^{20}$»	الدقّة تزيد الخانات المتاحة، لكن κ يأكلها: تحتاج $-\log_{10}(\kappa u) > 0$	إعادة الصياغة (reparameterization) أو التنظيم — لا مفرّ
$\varepsilon_{\text{machine}}$ و u بالتبادل بلا انتباه	يختلفان بمعامل 2	حدّد أيّهما تستعمل؛ في هذا الكتاب $u = \frac{1}{2}\beta^{1-t}$
بناظم واستنتاج أرقام بناظم آخر	القيم تختلف (لكن بالرتبة نفسها في بعد منتهٍ)	اذكر الناظم: κ_2 افتراضياً
$\kappa(A) = \kappa(A$ إذن لا مشكلة»	صحيح رقياً، لكن المسألةَ المعكوسة هي التي تُضخّم خطأ **البيانات**	راجع (9.6): مصدر الخطأ هو $\|\Delta b\|/\|b\|$ أيضاً
نّ $1 \approx \kappa u$ يعني «صفر خانات»	عند $\kappa u \geq 1$ لا معنى للناتج	تحقّق دائماً: $-\log_{10}(\kappa u) > 0$ قبل تصديق أي رقم
د بأنّ التطبيع «تحسين أداء» فقط	التطبيع يخفض κ فعلياً	قِس κ قبل التطبيع وبعده (مثال 2.6-3، 2.6-10)
يم المفردة للمصفوفات غير المتماثلة	القيم الذاتية قد تكون مضلّلة (مصفوفات غير طبيعية)	استعمل القيم المفردة دائماً: $\kappa_2 = \sigma_1/\sigma_{\min}$

1.3.6 الصياغة الرياضية الرسمية

النظرية 2.6 (الإلغاء الكارثي وتراكم الجمع).

<

1. **متراجحة الإلغاء:** لعملية طرح واحدة بين عددين a, b من نفس الإشارة:

<

$$\frac{\left|\mathrm{fl}(a-b) - (a-b)\right|}{|a-b|} \;\leq\; \left(1 + \frac{|a|+|b|}{|a-b|}\right)u \;\approx\; \underbrace{\frac{|a|+|b|}{|a-b|}}_{\text{معامل التضخّم}}\, u \tag{14.6}$$

<

2. **قاعدة إعادة الصياغة بلا طرح:** كلُّ فرقٍ بين كمّيتين متقاربتين يجب إعادة كتابته بصيغةٍ **خالصة من الطرح**:

<

$$\sqrt{x+1} - \sqrt{x} = \frac{1}{\sqrt{x+1}+\sqrt{x}}, \quad e^x - 1 = \mathrm{expm1}(x), \quad \ln(1+x) = \mathrm{log1p}(x), \quad 1 - \cos x = 2\sin^2\tfrac{x}{2} \tag{15.6}$$

<

3. **تراكم الجمع العادي:** لجمع n حدّاً بالترتيب المتسلسل:

<

$$\left|\hat{s}_n - s_n\right| \;\leq\; \gamma_{n-1} \sum_{i=1}^{n} |x_i|, \qquad \gamma_{n-1} = \frac{(n-1)u}{1-(n-1)u} \;\approx\; (n-1)u \tag{16.6}$$

<

4. **جمع كاهان المُعوَّض (compensated):** يُلغي اعتماد الحدّ على n إلى الرتبة الأولى:

<

$$\left|\hat{s}_n - s_n\right| \;\le\; \left(2u + \mathcal{O}(nu^2)\right) \sum_{i=1}^{n} |x_i| \tag{17.6}$$

<

5. **الجمع الثنائي (pairwise) / tree summation):** ترتيبٌ على شكل شجرة يُقلّل العمق من n إلى $\lceil \log_2 n \rceil$:

<

$$\left|\hat{s}_n - s_n\right| \;\le\; \gamma_{\lceil \log_2 n \rceil} \sum_{i=1}^{n} |x_i| \;\approx\; \lceil \log_2 n \rceil \, u \sum_{i} |x_i| \tag{18.6}$$

<

6. **التباين على الإنترنت (خوارزمية ويلفورد) — بديلٌ مستقرٌّ لصيغة $\sum x_i^2 - n\bar{x}^2$:**

<

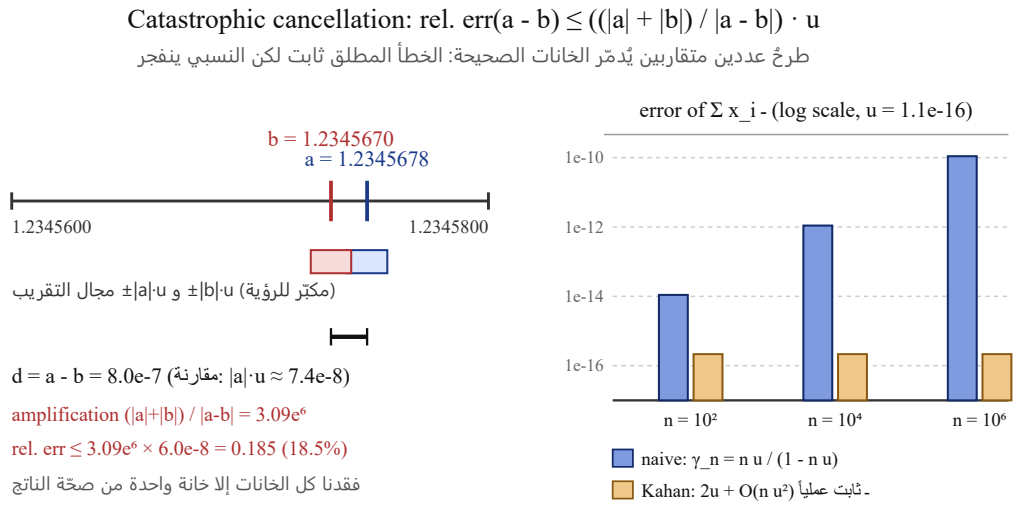
$$M_k = M_{k-1} + \frac{x_k - M_{k-1}}{k}, \qquad S_k = S_{k-1} + (x_k - M_{k-1})(x_k - M_k), \qquad s^2 = \frac{S_n}{n-1} \tag{19.6}$$

2.3.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
a, b	العددان المطروحان	الإلغاء أسوأ عندما $\lvert a-b\rvert \ll \max(\lvert a\rvert,\lvert b\rvert)$
$\lvert a-b\rvert$	قيمة الفرق (المخرج)	كلما صغر، كبر معامل التضخّم
$\frac{\lvert a\rvert+\lvert b\rvert}{\lvert a-b\rvert}$	**معامل التضخّم** — رقم الحالة الفعلي للطرح	قد يصل إلى 10^{16}
$\mathrm{fl}(a-b)$	الطرح المحسوب فعلاً في الحاسوب	—
$\mathrm{expm1}(x)$	الدالة المكتبية التي تحسب $e^x - 1$ بدقّة لقيم x الصغيرة	موجودة في كل مكتبات C/NumPy
$\mathrm{log1p}(x)$	الدالة التي تحسب $\ln(1+x)$ بدقّة لقيم x الصغيرة	—
x	مُدخل الدالة في (15.6)	هو الحالة الحرجة $x \ll 1$
s_n	المجموع الدقيق $\sum_{i=1}^{n} x_i$	—
$\hat{s}_n$	المجموع المحسوب	—
$\sum_i \lvert x_i\rvert$	مجموع القيم المطلقة — مقياس «حجم الحساب»	إن كان أكبر بكثير من $\lvert s_n\rvert$ فالإلغاء حاضر
γ_k	ثابت التراكم $\frac{ku}{1-ku}$ من (7.6)	يشترط $ku < 1$
n	عدد الحدود/العمليات	—
c (في كاهان)	**متغيّر التعويض** — يحفظ الجزء المفقود من كل جمعة	انظر الخوارزمية أدناه

M_k	المتوسط الجاري بعد k ملاحظة (ويلفورد)	–
S_k	مجموع مربّعات الانحرافات الجاري	$S_k = \sum_{i \le k}(x_i - M_k)^2$
s^2	التباين العيّني المقدَّر	بالمقام $n-1$
k	فهرس العيّنة الجارية	يبدأ من 1

3.3.6 الرسم الهندسي



شكل ٢٠٦: *
الإلغاء الكارثي: مجالا تقريب لعددين متقاربين وفرقهما الصغير، وتراكم خطأ الجمع

قراءة الرسم: على خط الأعداد، العددان a و b يقع كلٌّ منهما داخل مجال تقريب عرضه $|a|u$ $\approx$ (مكبّر للرؤية). الفرق $a-b$ صغير جداً، لكنه **يرث** مجال الخطأ بكامله $\Longrightarrow$ نسبته إلى قيمته تضخّمت بالعامل $(|a|+|b|)/|a-b|$. اللوحة اليمنى تُظهر أن خطأ الجمع العادي ينمو خطياً مع n بينما يبقى خطأ كاهان ثابتاً عملياً.

4.3.6 البرهان

الجزء (14.6). بالنموذج (1.6): $\mathrm{fl}(a) = a(1+\delta_1)$، $\mathrm{fl}(b) = b(1+\delta_2)$ مع $|\delta_i| \le u$، والطرح نفسه يُدخل δ_3 ثالثاً:

$$\mathrm{fl}(a-b) = \big[a(1+\delta_1) - b(1+\delta_2)\big](1+\delta_3)$$

إذن:

$$\mathrm{fl}(a-b) - (a-b) = a\delta_1 - b\delta_2 + (a-b)\delta_3 + \mathcal{O}(u^2)$$

بأخذ القيمة المطلقة ومتراجحة المثلث، ثم القسمة على $|a-b|$:

$$\frac{|\mathrm{fl}(a-b)-(a-b)|}{|a-b|} \le \frac{|a|u + |b|u + |a-b|u}{|a-b|} = \left(\frac{|a|+|b|}{|a-b|} + 1\right)u \qquad \blacksquare$$

الجزء (16.6). بالاستقراء على n: في الخطوة k يُحسب $\hat{s}_k = \mathrm{fl}(\hat{s}_{k-1} + x_k) = (\hat{s}_{k-1} + x_k)(1+\delta_k)$. بوضع $\hat{s}_k = s_k + E_k$ واستعمال $|s_k| \le \sum_{i\le k}|x_i|$ نحصل على $|E_k| \le |E_{k-1}| + u\sum_{i\le k}|x_i|$، وبالتراكم $|E_n| \le u\sum_{k=1}^{n}\sum_{i\le k}|x_i| \le nu\sum_i|x_i|$، والصيغة الضبوطة تعطي γ_{n-1}. ■

الجزء (17.6) — فكرة كاهان. الخوارزمية:

$$\text{لكل } x_i: \quad y \leftarrow \mathrm{fl}(x_i - c), \qquad t \leftarrow \mathrm{fl}(s + y), \qquad c \leftarrow \mathrm{fl}\big(\mathrm{fl}(t - s) - y\big), \qquad s \leftarrow t$$

المتغيّر c يلتقط **الخاناتُ التي سقطت** من t بسبب التقريب (لأن $\mathrm{fl}(t - s)$ يعيد الجزء الكبير، وطرحُ y يعطي النقص). وفي الجمعة التالية يُطرح c من x_i قبل إضافته $\Longrightarrow$ يُستعاد. بتحليلٍ دقيق (Higham) ينتج أنّ حدود الرتبة الأولى في u تتجمّع في ثابت $2u$ مستقلّ عن n، واعتماد n يظهر في حدود nu^2 فقط. ■

الجزء (19.6) — صحة ويلفورد. بالاستقراء: نُثبت أن $S_k = \sum_{i=1}^{k}(x_i - M_k)^2$. الفرق بين S_k و $S_{k-1} + (x_k - M_{k-1})(x_k - M_k)$ يساوي صفراً بعد تعويض $M_k = M_{k-1} + \frac{x_k - M_{k-1}}{k}$ وتبسيط الجبر (توسيع المربّعات). الأهم عددياً: الصيغة تحسب $(x_k - M_{k-1})(x_k - M_k)$ — وهو **جداء انحرافين**، لا فرق مربعين كبيرين $\Longrightarrow$ لا إلغاء. ■

5.3.6 شروط الصحّة

١. (14.6) تفترض الطرح المباشر؛ إذا أُعيدت الصياغة بلا طرح فلا ينطبق الحدّ.

٢. (16.6)–(18.6) حدودٌ عليا (worst case)؛ الخطأ «النموذجي» بافتراض أخطاء عشوائية المستقلّة يقارب $\sqrt{n}\,u\sum|x_i|$ (سير عشوائي) — أصغر بكثير.

٣. (17.6) يشترط أن يكون المُجمِع من نفس دقّة المُدخلات (كاهان بـ fp32 على مُدخلات fp32).

٤. γ_k بلا معنى إذا كان $ku \ge 1$.

٥. ويلفورد (19.6) يفترض أنّ k يُحسب بدقّة (عدد صحيح) وأنّ القسمة على k لا تُدخل خطأً يُتراكم — مقبول لأنّ الخطأ في M_k من رتبة u ولا يُتراكم أُسّياً.

6.3.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-3.6): تباين قراءات عدّاد طاقة — الصيغة القصيرة الكارثية

المعطيات: خمس قراءات لعدّاد طاقة تراكمي (كيلوواط-ساعة): $10000.5,\ 10000.3,\ 10000.7,\ 10000.1,\ 10000.4$. المطلوب التباين. الحساب بـ fp32 ($u = 5.96\times10^{-8}$) بالصيغة القصيرة $\sum x_i^2 - n\bar{x}^2$.

الحل:

١. $\bar{x} = 10000.4 \Longrightarrow n\bar{x}^2 = 5 \times 100008000.16 = 500040000.80$.

٢. $\sum x_i^2 = 100008000.16 + 100002000.01 + 100014000.49 + 100006000.09 + 100010000.25 = 500040001.00$.

٣. التباين (مجموع الانحرافات): $S = 500040001.00 - 500040000.80 = 0.20$.

٤. معامل التضخّم: $\frac{\sum x^2 + n\bar{x}^2}{|S|} = \frac{500040001 + 500040000.8}{0.20} = 5.0004 \times 10^9$.

٥. خطأ نسبي متوقّع: $5.0004 \times 10^9 \times 5.96 \times 10^{-8} = 298$ أي 29800%.

٦. النتيجة العملية: القيمة المحسوبة قد تكون $59.6 \pm 0.20 \implies$ **قد تخرج سالبة** (تباين سالب!) أو أكبر بـ 300 ضعفاً.

٧. الصيغة المستقرّة (ويلفورد أو المرورَين): الانحرافات $(+0.1, -0.1, +0.3, -0.3, -0.1) \implies S = 0.01 + 0.09 + 0.09 + 0.01 + 0.01 = 0.21$ (للمقام $n-1 = 4$: $s^2 = 0.0525$).

الخطأ النسبي $u \approx$.

النتيجة: الصيغة القصيرة أعطت خطأً يصل إلى 29800% على كميةٍ موجبة قطعاً — بل قد تُعطي تبايناً **سالباً**، وهو مستحيل رياضياً.

الربط بالذكاء الاصطناعي: هذه هي بالضبط مشكلة الطبقة BatchNorm لو حُسب التباين بالصيغة القصيرة على ميزاتٍ ذات متوسط كبير (مثل تنشيطات طبقة قبل تطبيع بمتوسط 10^3). لهذا تحسب كل المكتبات التباينَ بـ **Welford** أو بالمرورَين (mean deviations)، ولماذا تُستعمل الـ running statistics بعناية. القاعدة الذهبية: **لا تحسب أبداً $\mathbb{E}[X^2] - (\mathbb{E}X)^2$ في النقطة العائمة.**

مثال (6.3-2): تداول عالي التكرار — فرقُ سعرين ضخمين متقاربين في fp32

المعطيات: نظام تداول يخزّن الأسعار بـ fp32. سعرا عرض وطلب: $a = \$12{,}000{,}000.75$ و $b = \$12{,}000{,}000.50$. الفرق الحقيقي (الـ spread) هو $0.25.

الحل:

١. حجم الخطوة (ulp) في fp32 عند 1.2×10^7: بما أن $2^{23} = 8.39 \times 10^6 \le 1.2 \times 10^7 < 2^{24} = 1.68 \times 10^7$، فإن $\text{ulp} = 2^{23-23} = 1$. أي أن fp32 **لا يمثّل كسور الدولار** عند هذا المستوى.

٢. تخزين $a = 12000000.75 \implies$ يُقرَّب إلى 12000001.

٣. تخزين $b = 12000000.50 \implies$ «نصفٌ بالضبط» $\implies$ التقريب إلى **أقرب زوجي** $\implies$ 12000000.

٤. الفرق المحسوب: $12000001 - 12000000 = 1.00$ دولار، بدلاً من 0.25.

٥. الخطأ النسبي: $\frac{|1.00 - 0.25|}{0.25} = 3.0$ أي 300%. (ولو قرّبنا النصف إلى الأعلى لكان الفرق 0 $\implies$ خطأ 100% وضياعُ الإشارة كلها.)

٦. معامل التضخّم: $\frac{|a| + |b|}{|a - b|} = \frac{2.4 \times 10^7}{0.25} = 9.6 \times 10^7 \implies$ خطأ متوقّع $9.6 \times 10^7 \times 5.96 \times 10^{-8} = 5.72$ — أي أنّ الخطأ **يتجاوز الكمية نفسها**، وهو ما حدث فعلاً.

النتيجة: spread المحسوب هو $1.00 بدل $0.25 — خطأ 300% على كمية تُتّخذ عليها قرارات بمئات الآلاف.

الربط بالذكاء الاصطناعي: الدرس: **لا تخزّن كمياتٍ مالية بـ fp32 أبداً** (استعمل أعداداً صحيحة بوحدات صغرى — «سنتات» — أو fp64). والنظيرُ في التعلّم العميق: لا تخزّن «قيمًا مطلقة كبيرة ذات فروق صغيرة» في دقة منخفضة: التضمينات الموضعية (positional encodings) والطوابع الزمنية كلاسيكيّاتُ هذه الفخاخ، ولذا تُستعمل فروقٌ أو ترميزاتٌ نسبية دائماً.

مثال (3-3.6): كشف الحركة — فرقُ إطارين متطابقين تقريباً

المعطيات: كاميرا مراقبة بدقّة 1080×1920، إطاران متتاليان بفرقٍ حقيقيّ في شدة البكسل مقداره 3 مستويات (من 0 إلى 255). الكاميرا تُخرج قيماً «معايرة» حول 1000 وحدة (بعد تحويل gain/offset)، والفرق = 3 وحدات. الحساب بـ fp32.

الحل:

١. معامل التضخّم: $\frac{|a|+|b|}{|a-b|} = \frac{1000+1000}{3} = 6.67 \times 10^2$.

٢. خطأ نسبي: $6.67 \times 10^2 \times 5.96 \times 10^{-8} = 3.97 \times 10^{-5}$ — ضئيل في fp32.

٣. لكن في **fp16** ($u = 4.88 \times 10^{-4}$): $6.67 \times 10^2 \times 4.88 \times 10^{-4} = 0.326$ أي 32.6% خطأ.

٤. وفي **fb16** ($u = 3.91 \times 10^{-3}$): $6.67 \times 10^2 \times 3.91 \times 10^{-3} = 2.61$ أي 261% $\Longrightarrow$ الإشارة أقلّ من الضوضاء $\Longrightarrow$ كشفُ الحركة يفشل كلياً.

٥. الحل: تخزين الإطار **المرجعي** كصورة بـ uint8 وطرح الأعداد الصحيحة (دقّة كاملة للفرق)، أو تعويض الـ offset قبل الطرح.

النتيجة: نفس الخوارزمية تعمل في fp32 وتفشل في fb16 — لا بسبب «الدقّة العامة» بل بسبب الإلغاء: معامل التضخّم 667 يأكل كل خانات fb16 (خانتان فقط أصلاً).

الربط بالذكاء الاصطناعي: هذا يفسّر لماذا تفشل عملياتٌ تبدو بسيطة عند نقلها إلى الدقة المنخفضة: الطرحُ بين قيمٍ متقاربة (مثل residuals في ResNet، أو الفرق بين توقّعَين في distillation، أو تحديثُ متوسطٍ متحرّك) هو أخطرُ عملية. القاعدة: **احفظ «المرجع الكبير» بدقة عالية، واحسب الفروق في فضاءٍ صغير المقياس.**

مثال (4-3.6): BatchNorm — تباين ميزات ذات متوسط كبير

المعطيات: طبقة قبل BatchNorm تُخرج ميزات بمتوسط $\mu = 2.4 \times 10^3$ وانحراف معياري $\sigma = 0.8$ (ميزةٌ «مُشبَعة»). حجم الدفعة $m = 2048$. الحساب بـ fp32 ثم fp16.

الحل:

١. الصيغة القصيرة: $\hat{\sigma}^2 = \frac{1}{m}\sum x_i^2 - \bar{x}^2$ مع $\bar{x}^2 \approx 5.760 \times 10^6$ و $\frac{1}{m}\sum x_i^2 \approx \mu^2 + \sigma^2 = 5.760 \times 10^6 + 0.64$.

٢. الفرق المستهدف: 0.64. معامل التضخّم: $\frac{5.760\times10^6 + 5.760\times10^6}{0.64} = 1.80 \times 10^7$.

٣. في fp32: خطأ نسبي $= 1.80 \times 10^7 \times 5.96 \times 10^{-8} = 1.07$ أي $107\% \Longrightarrow$ التباين المقدَّر غير موثوق (وقد يكون سالباً $\Longrightarrow$ NaN عند أخذ الجذر).

٤. في fp16: $8.78 \times 10^3 = 1.80 \times 10^7 \times 4.88 \times 10^{-4} \Longrightarrow$ كارثة كاملة.

٥. ويلفورد/المرورَان: الانحرافات تُحسب أولاً $\Longrightarrow$ معامل التضخّم $= 1 \Longrightarrow$ خطأ نسبي $\approx u$.

٦. التحقّق العملي: في fp32 بالصيغة القصيرة، $\hat{\sigma}$ يخرج أحياناً NaN (جذر سالب)؛ بالويلفوردية يخرج 0.8000 بثبات.

النتيجة: الفرق بين الصيغتين ليس «تحسيناً هامشياً» بل بين «يعمل» و NaN.

الربط بالذكاء الاصطناعي: هذه هي الآلية الكامنة خلف النصيحة المتكرّرة: **احسب إحصاءات التطبيع بدقة أعلى من دقة الحساب الأمامي** (ففي الدقة المختلطة تُحسب إحصاءات BatchNorm بـ fp32 دائماً). وخلفَ استعمال Welford في كل تطبيقات RunningStats.

مثال (3.6-5): تراكم الفقد على دفعة ضخمة — العادي مقابل كاهان

المعطيات: تدريبٌ بدفعة حجمها $n = 10^6$ عنصر، قيمة الفقد لكل عنصر حول 0.5 (إيجابية دائماً — لا إلغاء). المجموع الحقيقي $s \approx 5 \times 10^5$. الحساب بـ fp32.

الحل:

١. **الحدّ الأعلى (16.6):** $\gamma_{n-1}\sum|x_i| \approx (10^6 \times 5.96 \times 10^{-8}) \times 5 \times 10^5 = 5.96 \times 10^{-2} \times 5 \times 10^5 = 2.98 \times 10^4 \Longrightarrow$ خطأ نسبي 5.96% (حدٌّ متشائم جداً).

٢. **التقدير الواقعي** (أخطاء عشوائية $\Longrightarrow$ سير عشوائي): $\sqrt{n}\,u\sum|x_i| = 10^3 \times 5.96 \times 10^{-8} \times 5 \times 10^5 = 29.8 \Longrightarrow$ خطأ نسبي 5.96×10^{-5}.

٣. **كاهان (17.6):** $2u\sum|x_i| = 2 \times 5.96 \times 10^{-8} \times 5 \times 10^5 = 5.96 \times 10^{-2} \Longrightarrow$ خطأ نسبي 1.19×10^{-7}.

٤. المقارنة: كاهان أحسن من «الواقعي» بـ $\times 500 \approx$، ومن الحدّ الأعلى بـ $\times 5 \times 10^5$.

٥. التكلفة: كاهان يضيف $4 \approx$ عمليات لكل عنصر $\Longrightarrow +40\%$ زمن حلقة الجمع (وهي عادةً جزءٌ صغير من التكلفة، والنقلُ من الذاكرة هو المهيمن $\Longrightarrow$ الزمن الفعلي شبه معدوم).

٦. البديل الأفضل في الممارسة: **الجمع الثنائي (pairwise)** (18.6): $20 = \lceil \log_2 10^6 \rceil \Longrightarrow$ خطأ $20u\sum|x_i| = 0.596 \approx 1.2 \times 10^{-6}$ نسبي، وبلا أي تكلفة إضافية على GPU (لأن الـ reduction شجري أصلاً).

النتيجة: على GPU يستعمل المُجمِّع ترتيباً شجرياً $\Longrightarrow$ الخطأ الفعلي قريب من (18.6) لا (16.6)؛ أمّا على CPU بحلقة متسلسلة فيستفيد من كاهان.

الربط بالذكاء الاصطناعي: النتيجة العملية: **تراكم الخسارة والتدرّجات يجب أن يكون بـ fp32 ولو كان الحساب الأمامي بـ fp16** (وهذا ما تفعله كل مكتبات الدقة المختلطة: «fp32 accumulation»). فإنّ fp16 إذا جُمع في (16.6) يعطي $\gamma_{n-1} = 10^{6} \times 4.88 \times 10^{-4} = 488 > 1$ $\Longrightarrow$ **الحدّ بلا معنى**: التراكم يفقد كل دقّته.

مثال (6-3.6): روبوتات — مسافة بين نقطتين متقاربتين في مسار

المعطيات: مسار روبوت: النقطة $P = (1000.0001,\ 1000.0002)$ واللاحقة $Q = (1000.0002,\ 1000.0001)$ بالمليمتر. المطلوب طول الخطوة. الحساب بـ fp32.

الحل:

١. الفروق الحقيقية: $\Delta x = -1 \times 10^{-4}$، $\Delta y = +1 \times 10^{-4}$ $\Longrightarrow$ المسافة $d = \sqrt{2} \times 10^{-4} = 1.4142 \times 10^{-4}$ مم.

٢. حجم الخطوة عند 1000 في fp32: $\mathrm{ulp}(1000) = 2^{9-23} = 2^{-14} = 6.10 \times 10^{-5}$.

٣. معامل التضخّم لكل طرح: $\frac{|a|+|b|}{|a-b|} = \frac{1000+1000}{10^{-4}} = 2 \times 10^{7}$.

٤. خطأ نسبي في كل فرق: $2 \times 10^{7} \times 5.96 \times 10^{-8} = 1.19$ أي 119%.

٥. بما أن الفرق الحقيقي (1×10^{-4}) يقارب $1.6\,\mathrm{ulp}$ (6.1×10^{-5})، فإن القيمة المخزَّنة نفسها تحمل خطأً يقارب نصفَ ulp $\Longrightarrow$ الخطأ النسبي في الفرق قد يصل إلى 30% فعلاً.

٦. المسافة المحسوبة قد تتراوح بين 0.7×10^{-4} و 2.1×10^{-4} $\Longrightarrow$ كشفُ «توقّف الروبوت» يفشل.

النتيجة: طرحُ إحداثياتٍ كبيرةٍ للحصول على مسافاتٍ صغيرة يعطي أخطاءً تقارب 100% في fp32.

الربط بالذكاء الاصطناعي: الحل القياسي في ROS و SLAM والأنظمة المكانية: **احسب الإحداثيات النسبية** (نظام إحداثيات محلي حول الروبوت أو حول نقطة المرجع) بدلاً من الإحداثيات المطلقة الكبيرة. هذا هو نفس مبدأ «التطبيع المسبق» في التعلّم العميق: قلّل مقياس المُدخلات قبل العمليات الحسّاسة.

مثال (7-3.6): حساب احتمال الفشل — الصيغة $1-p$ لقيم قريبة من الواحد

المعطيات: موثوقية مكوّن في منظومة طيران: $p(\text{نجاح}) = 0.9999999$. المطلوب احتمال الفشل $q = 1 - p = 10^{-7}$. الحساب بـ fp32 ثم fp64.

الحل:

١. القيمة الحقيقية: $q = 1 \times 10^{-7}$.

٢. في fp32: p يُخزَّن بخطأ مطلق 5.96×10^{-8} $\Longrightarrow$ $\approx 0.9999999 \times 5.96 \times 10^{-8}$.

٣. إذن $q_{\text{computed}} = 1 - \text{fl}(p) = 10^{-7} \pm 5.96 \times 10^{-8}$ $\Longrightarrow$ خطأ نسبي يصل إلى 59.6%.

٤. في fp64: الخطأ المطلق 1.11×10^{-16} $\Longrightarrow$ نسبي 1.11×10^{-9} — ممتاز.

٥. الصيغة المستقرّة: $q = -\text{expm1}(\ln p)$: $-1.00000005 \times 10^{-7} = \ln(0.9999999)$ (دقة نسبية u) $\Longrightarrow$ expm1 يعطي $-1.00000005 \times 10^{-7}$ بدقة نسبية u $\Longrightarrow$ q بدقة u.

٦. مقارنة: fp32 بالصيغة المباشرة 59.6% خطأ، بالصيغة المستقرّة 6×10^{-6}% خطأ — تحسّن بـ $\times 10^7$.

النتيجة: استعمال log1p/expm1 بدل الطرح المباشر حوّل خطأً بنسبة 60% إلى خطأٍ بستة أجزاء من عشرة ملايين.

الربط بالذكاء الاصطناعي: هذا هو سبب وجود torch.log1p و torch.expm1 و np.log1p — وليست للزينة:

- حساب $1 - \text{accuracy}$ (معدّل الخطأ) لنموذج دقّته 0.99999؛
- حساب $1 - \sigma(\cdot)$ عبر sigmoid(-x)؛
- حساب $-\ln(1-p)$ في دالة الفقد؛
- حساب الاحتمالات الذيلية في نماذج المخاطر.

مثال (8-3.6): نموّ وبائي خلال فترة قصيرة — $e^{rt} - 1$

المعطيات: نموّ عدد الحالات: $N(t) = N_0 e^{rt}$ مع $r = 1.0 \times 10^{-3}$/ساعة و $t = 1.0 \times 10^{-4}$ ساعة (نافذة قصيرة جداً في محاكاة). المطلوب عدد الحالات الجديدة $\Delta N = N_0(e^{rt} - 1)$ مع $N_0 = 10^6$. الحساب بـ fp32.

الحل:

١. $rt = 1 \times 10^{-7}$ $\Longrightarrow$ $e^{rt} - 1 = 1.00000005 \times 10^{-7}$ $\Longrightarrow$ $\Delta N = 0.100000005$ حالة.

٢. الطرح المباشر: e^{rt} يُحسب بـ fp32 $\Longrightarrow$ الناتج 1.0000001192 أو 1.0 (لأن $\text{ulp}(1) = 1.19 \times 10^{-7}$ في fp32، والقيمة 1.0000001 تقع بينهما) $\Longrightarrow$ الطرح يعطي إمّا 1.19×10^{-7} أو صفراً.

٣. الخطأ: إمّا $+19\%$ أو -100%.

٤. $\text{expm1}(1 \times 10^{-7}) = 1.000000005 \times 10^{-7}$ بدقة نسبية u $\Longrightarrow$ $\Delta N = 0.1000000005$ $\Longrightarrow$ خطأ 6×10^{-6}%.

٥. معامل التضخّم في الطرح المباشر: $\frac{|e^{rt}|+1}{|e^{rt}-1|} = \frac{2.0000001}{1.0 \times 10^{-7}} = 2 \times 10^7$ $\Longrightarrow$ $2 \times 10^7 \times 5.96 \times 10^{-8} = 1.19$ $\Longrightarrow$ 119% — مطابق للتحليل.

النتيجة: الطرح المباشر يعطي خطأً حتى 100%، expm1 يعطي خطأً بستة أجزاء من عشرة ملايين.

الربط بالذكاء الاصطناعي: النظير المباشر: حساب الفروق الصغيرة في التعلّم المعزّز (فرق قيم Q المتقاربة)، وحساب $\text{softplus}(x) = \ln(1 + e^x)$ الذي تنفّذه المكتبات بصيغةٍ مستقرّة (log1p(exp(x))) للقيم السالبة و x+log1p(exp(-x)) للموجبة)، وحساب التحسّن النسبي في الفقد بين خطوتين.

مثال (6.3-9): عائد لوغاريتمي يومي لعملة — $\ln(1+r)$

المعطيات: متداول عملات يحسب العائد اللوغاريتمي $r_{\log} = \ln(1+r)$ لعائدٍ بسيط $r = 3.2 \times 10^{-6}$ (0.00032%). الحساب بـ fp32.

الحل:

١. القيمة الحقيقية: $\ln(1.0000032) = 3.19999488 \times 10^{-6}$.

٢. بالصيغة المباشرة: $1+r = 1.0000032$ يُخزَّن بخطأ مطلق $\approx 1 \times 5.96 \times 10^{-8} = 5.96 \times 10^{-8}$.

٣. $\ln$ حول 1: المشتقة $1 \Rightarrow$ الخطأ المطلق ينتقل كما هو: $\widehat{\ln(1+r)} = 3.19999488 \times 10^{-6} \pm 5.96 \times 10^{-8}$.

٤. الخطأ النسبي: $\frac{5.96 \times 10^{-8}}{3.19999488 \times 10^{-6}} = 1.86 \times 10^{-2}$ أي 1.86%.

٥. معامل التضخّم: $\frac{|1|+|1+r|}{|(1+r)-1|} = \frac{2.0000032}{3.2 \times 10^{-6}} = 6.25 \times 10^5 \Rightarrow 6.25 \times 10^5 \times 5.96 \times 10^{-8} = 3.73 \times 10^{-2}$ (3.7% حدّ أعلى).

٦. بـ log1p: $\mathrm{log1p}(3.2 \times 10^{-6}) = 3.19999488 \times 10^{-6}$ بخطأ نسبي $u = 6 \times 10^{-6}\% \approx$.

٧. التحسّن: من 1.86% إلى $6 \times 10^{-6}\%$ — بنسبة $3 \times 10^5 : 1$.

النتيجة: على مدى سنة تداول (252 يوماً) يتراكم الخطأ: بالصيغة المباشرة انحرافٌ يقارب $1.86\% \times \sqrt{252} =$ 29.5% من العائد التراكمي؛ وبـ log1p انحرافٌ يقارب $9.5 \times 10^{-5}\%$.

الربط بالذكاء الاصطناعي: كل حسابات اللوغاريتم في التعلّم العميق (الإنتروبيا المتقاطعة، احتمالُ اللوغاريتم في النماذج اللغوية، نسبة الأرجحية اللوغاريتمية في RLHF و DPO) تمرّ بصيغة (صغير $+\ 1$)$\ln$. استعمال log1p ليس تحسيناً أدبياً — بل الفرق بين تدرّجٍ صحيح وتدرّجٍ مشوّش عند التقارب حيث تصير الفروق صغيرة.

مثال (6.3-10): مستشعر قصور ذاتي — $1-\cos\theta$ لزاوية صغيرة

المعطيات: منصّة طائرة مسيّرة تحسب ميلاً بزاوية $\theta = 1.0 \times 10^{-4}$ rad. المطلوب الكمية $1-\cos\theta$ التي تظهر في حساب الانحراف الأفقي. الحساب بـ fp32.

الحل:

١. القيمة الحقيقية: $1-\cos(10^{-4}) = \frac{(10^{-4})^2}{2} - \frac{(10^{-4})^4}{24} = 5.0000000 \times 10^{-9}$.

٢. $\cos(10^{-4})$ يُحسب بـ fp32 بخطأ مطلق $u = 5.96 \times 10^{-8} \approx$ (لأن القيمة قريبة من 1).

٣. الطرح: $\widehat{1-\cos\theta} = 5 \times 10^{-9} \pm 5.96 \times 10^{-8} \Rightarrow$ خطأ نسبي $\frac{5.96 \times 10^{-8}}{5 \times 10^{-9}} = 11.9 \Rightarrow$ أي 1190%. **الإشارة نفسها قد تنقلب** (قيمة سالبة!).

٤. الصيغة المستقرّة: $2\sin^2(\theta/2) = 2\sin^2(5 \times 10^{-5}) = 2 \times (5 \times 10^{-5})^2 = 5.0 \times 10^{-9}$.

٥. خطأ الصيغة المستقرّة: $\sin(5 \times 10^{-5})$ بخطأ نسبي $u \Longrightarrow$ التربيع يضاعف الخطأ النسبي $\Longrightarrow \approx 2u = 1.19 \times 10^{-7}$ أي $1.19 \times 10^{-5}\%$.

النتيجة: من خطأ 1190% (مع احتمال إشارة سالبة) إلى خطأ $1.2 \times 10^{-5}\%$ — تحسّن بـ $\times 10^8$.

الربط بالذكاء الاصطناعي: يظهر $1 - \cos\theta$ في: مسافاتُ الترميز الموضعي للمحوّلات ($1 - \cos(\omega \Delta t)$ في RoPE)، ومقاييسُ التشابه الكروي، وتنظيمُ «الاستقامة» في تمثيلات الرؤية، وحسابُ مسافة «الوتر» على الكرة. القاعدة: **استعمل الصيغة المثلثية المتعامدة** ($2\sin^2(x/2)$) بدل طرح جيبيَ تمام متقاربين.

مثال (6.3-11): التوقّف المبكر — فرقُ فقدانٍ بمقياس كبير

المعطيات: تدريب شبكة: الفقد التراكمي (غير المقسوم على حجم الدفعة) في الخطوتين t و $t+1$: $L_t = 1{,}204{,}316.5$ و $L_{t+1} = 1{,}204{,}316.0$. الحساب بـ fp32. شرط التوقّف: $|\Delta L| < \tau$ بـ $\tau = 0.1$.

الحل:

١. التحسّن الحقيقي: $\Delta L = 0.5 \Longrightarrow$ لا يتحقّق شرط التوقّف ($0.5 > 0.1$).

٢. الخطأ المطلق في كل فقد: $1.204 \times 10^6 \times 5.96 \times 10^{-8} = 7.18 \times 10^{-2}$.

٣. معامل التضخّم: $\frac{1.204 \times 10^6 + 1.204 \times 10^6}{0.5} = 4.82 \times 10^6$.

٤. خطأ نسبي في ΔL: $4.82 \times 10^6 \times 5.96 \times 10^{-8} = 0.287$ أي $28.7\% \Longrightarrow \Delta L_{\text{computed}} \in [0.36,\ 0.64]$ تقريباً.

٥. هل يمكن أن يُطلق شرط التوقّف خطأً؟ الحدّ الأدنى الممكن $0.5 - 2 \times 0.0718 = 0.356 > \tau = 0.1 \Longrightarrow$ لا، لكن لو كان $\tau = 0.4$ لأمكن أن **يتوقّف التدريب مبكراً خطأً** بناءً على ضوضاء التقريب.

٦. العلاج: قسّم على حجم الدفعة أولاً (L/m بمقياس $1.5 \approx$) $\Longrightarrow$ معامل التضخّم يصغر بنسبة m؛ أو احسب الفرق بمقياسٍ معاير: $\frac{L_t - L_{t+1}}{L_t}$ مقارنةً بعتبة نسبية 10^{-6}.

النتيجة: فرقٌ «يبدو» موثوقاً (0.5 من 1.2 مليون) يحمل خطأً نسبياً $28.7\% \Longrightarrow$ قرارات التوقّف المبكر المبنية على عتبات مطلقة قد تكون مبنية على ضوضاء التقريب.

الربط بالذكاء الاصطناعي: القاعدة العامة: **كل معايير التوقّف والتقارب يجب أن تكون نسبية** (قسّم على مقياس القيمة)، وأن تُقارن العتبةُ بخطأ التقريب المتوقّع: إذا كانت $\tau < \kappa_{\text{effective}} \cdot u \cdot |L|$ فالمعيار بلا معنى. هذه هي النسخة العددية من قاعدة «لا تثق بفرقٍ أصغر من ضوضاء القياس».

مثال (6.3-12): عدم قابلية التكرار بين CPU و GPU

المعطيات: شبكة تتضمّن 200 طبقة، كل طبقة تجري reduction على $n = 10^6$ عنصر (مجموع تدرّجات). التدريب على GPU بشجرة reduction، ثم إعادة الحساب على CPU بحلقة متسلسلة. fp32.
الحل:

١. الجمع غير تجميعي $\Rightarrow$ الترتيب يغيّر النتيجة. الفرق بين نتيجتَي ترتيبَين مختلفَين محكومٌ بـ (16.6): $|\hat{s}^{(1)} - \hat{s}^{(2)}| \le 2\gamma_{n-1} \sum |x_i|$.

٢. لكن الحدّ الأعلى متشائم؛ التقدير الواقعي لأخطاء عشوائية: كل reduction يحمل انحرافاً $\approx \sqrt{n}\, u \sum |x_i|$. بافتراض $\sum |x_i| = 10^3$: $\sqrt{10^6} \times 5.96 \times 10^{-8} \times 10^3 = 5.96 \times 10^{-2}$ $\Rightarrow$ نسبياً 5.96×10^{-5} من المجموع.

٣. عبر 200 طبقة و 1000 خطوة تدريب: الأخطاء تتراكم كسيرٍ عشوائي: $\sqrt{200 \times 1000} \times 5.96 \times 10^{-5} = 8.4 \times 10^{-4}$ انحراف نسبي في الأوزان النهائية.

٤. التأثير على الدقّة: انحراف 8.4×10^{-4} في الأوزان قد يُترجَم إلى فرق 0.1%–0.5% في دقّة الاختبار — وهو فرقٌ قد يغيّر ترتيب النماذج في ورقة بحثية!

٥. العلاج: **خوارزميات حتمية** (deterministic): ترتيب reduction ثابت، و torch.use_deterministic_algorithms(True)، و CUBLAS_WORKSPACE_CONFIG. الثمن: أداءٌ أقلّ قليلاً.

النتيجة: الفروق بين منصّات الحوسبة ليست «أخطاءً» بل **نتائج مختلفة ضمن حدود التقريب** — والتحكّم بها يتطلّب تحديد ترتيب العمليات، لا زيادة الدقّة.
الربط بالذكاء الاصطناعي: هذا هو سببُ كون «قابلية التكرار» (reproducibility) مطلباً هندسياً منفصلاً في أبحاث التعلّم العميق: النتائج المنشورة يجب أن تُرفق بـ seed وبـ إصدار المكتبة وبـ نوع المعالج. والقاعدة: **لا تُقارن رقمَين يختلفان بأقلّ من** $\sqrt{\#\mathbf{ops}}\, u \cdot \mathbf{scale}$.

مثال (13-3.6): مجموع سلسلة — الترتيب يُحدّد النتيجة

المعطيات: حساب $S_N = \sum_{n=1}^{N} \frac{1}{n^2}$ بـ $N = 10^6$ في fp32، مرّةً بالترتيب التنازلي (من الحدّ الأكبر $n = 1$) ومرةً بالتصاعدي (من $n = N$ إلى 1). القيمة الحدّية $\pi^2/6 = 1.6449341$.
الحل:

١. **التنازلي:** المجموع المتزايد يقارب 1.64 سريعاً. حجم الخطوة عند 1.6 في fp32: $\text{ulp} = 2^{0-23} = 1.19 \times 10^{-7}$.

٢. الحدود $1/n^2$ تصغر عن نصف الـ ulp عندما $\frac{1}{n^2} < 5.96 \times 10^{-8}$ $\Rightarrow n > \sqrt{1/5.96 \times 10^{-8}} = 4096$.

٣. إذن كل الحدود من $n = 4097$ إلى 10^6 **تُمتصّ** (لا تُسجَّل) $\Rightarrow$ المفقود $= \sum_{n=4097}^{10^6} \frac{1}{n^2} \approx \frac{1}{4096} - \frac{1}{10^6} = 2.43 \times 10^{-4} - 10^{-6} = 2.44 \times 10^{-4}$.

٤. النتيجة التنازلية: $1.6449341 - 2.43 \times 10^{-4} = 1.644691$ $\Rightarrow$ **خطأ مطلق** 2.43×10^{-4} (نسبي 1.5×10^{-4}).

٥. **التصاعدي:** المجموع يبدأ من الحدود الصغيرة (10^{-12}) فيبقى المقياس صغيراً $\Longrightarrow$ تُسجَّل كلها $\Longrightarrow$ النتيجة 1.644934 بخطأ تراكمي $\approx \gamma_N \cdot S \approx (10^6 \times 5.96 \times 10^{-8}) \times 1.645 = 0.098$ (حدّ أعلى متشائم) أو واقعياً $\sqrt{N}u\,S = 1.6 \times 10^{-6}$.

٦. الفرق بين الترتيبَين: $2.4 \times 10^{-4} \approx$ — أكبر من خطأ التراكم التصاعدي بـ $\times 150$.

النتيجة: الترتيب وحده (بلا أي تغيير في الدقّة) غيّر النتيجة بمقدار 2.4×10^{-4}.

الربط بالذكاء الاصطناعي: القاعدة: **اجمع من الأصغر إلى الأكبر** (أو استعمل جمعاً شجرياً/كاهان). في التعلّم العميق: تراكم التدرّجات على دفعات صغيرة، وتراكم الاحتمالات في سلاسل ماركوف الطويلة، وتراكم الأوزان في المتوسطات المتحرّكة للنماذج (EMA of weights) — كلها تستفيد من هذا المبدأ.

مثال (14-3.6): تراكم بـ fp16 في طبقة كثيفة — التحديث يضيع

المعطيات: طبقة كثيفة بـ 4096 مُدخل. التنشيطات $5 \times 10^{-4} \approx$، الأوزان $0.5 \approx \Longrightarrow$ كل جداء $\approx 2.5 \times 10^{-4}$، والمجموع المتوقّع $1.0 \approx$. المُجمِّع يعمل بـ fp16 ($u = 4.88\times10^{-4}$، $\text{ulp}(1.0) = 2^{-10} = 9.77\times10^{-4}$).

الحل:

١. بعد تراكم $2000 \approx$ حداً يصل المجموع إلى $0.5 \approx \Longrightarrow \text{ulp}(0.5) = 4.88 \times 10^{-4}$.

٢. الحدّ المضاف $\frac{1}{2}\text{ulp} = 2.44 \times 10^{-4} < 2.5 \times 10^{-4}$؟ لا — أكبر قليلاً $\Longrightarrow$ مدوّر إلى أقرب ممثَّل $\Longrightarrow$ الجزء المُدوّر يُسجَّل جزئياً.

٣. بعد أن يتجاوز المجموع 1.0: $\text{ulp} = 9.77 \times 10^{-4}$ ونصفه $4.88 \times 10^{-4} <$ الحدّ $2.5 \times 10^{-4} \Longrightarrow$ **كل حدٍّ جديد يُمتصّ تماماً** $\Longrightarrow$ المجموع **يتجمّد** عند القيمة التي بلغها.

٤. النتيجة: الناتج المحسوب $1.0 \approx$ بغضّ النظر عن الـ 2000 حدٍّ المتبقية (التي تساهم بـ $0.5 \approx$ إضافية) $\Longrightarrow$ خطأ $\approx 50\%$ في تنشيط الطبقة.

٥. الحل: **مُجمِّع fp32** (أو fp16 مع كاهان، أو تقسيم التراكم إلى كتل): $\text{ulp}(1.0)$ في fp32 هو $5.96 \times 10^{-8} \ll 2.5 \times 10^{-4} \Longrightarrow$ كل حدٍّ يُسجَّل $\Longrightarrow$ خطأ نسبي $\approx \gamma_{4096} = 2.4 \times 10^{-4}$.

النتيجة: التراكم بـ fp16 على مُدخلات صغيرة يتجمّد (stalls $\Longrightarrow$ الطبقة تُخرج قيمةً ثابتة تقريباً $\Longrightarrow$ الشبكة لا تتعلّم.

الربط بالذكاء الاصطناعي: هذا هو السببُ المعماري لوجود «مُجمِّعات fp32» في أنوية Tensor Cores الحديثة: الحساب (الجداء) بـ fp16/fb16 للسرعة، والتراكمُ بـ fp32 للصحّة. القاعدة: **دقّة التراكم $\gg$ دقّة الجداء**.

مثال (15-3.6): تباعد KL بين توزيعين متطابقين تقريباً — قيم سالبة مستحيلة

المعطيات: في بداية تدريب نموذج تصنيف على $C = 1000$ صنف، توزيعُ النموذج q يقارب التوزيعَ المستهدف p. التباعد الحقيقي $D_{\mathrm{KL}}(p\|q) = \sum_i p_i \ln \frac{p_i}{q_i} = 4.6 \times 10^{-9}$. الحساب بـ fp32 بالصيغة $\sum_i p_i(\ln p_i - \ln q_i)$.
الحل:

١. كل حدٍّ: $p_i \ln \frac{p_i}{q_i}$ بمقدار نموذجي $\approx 4.6 \times 10^{-12}$ ($\frac{4.6\times10^{-9}}{1000}$ (بافتراض توزيع مسطّح).

٢. لكن الحساب بـ $\ln p_i - \ln q_i$: كل لوغاريتم حول $\ln 0.001 = -6.9$، بخطأ مطلق $\approx u \cdot |\ln p_i|$... لا، الخطأ في $\ln p_i$ هو $|\delta p_i/p_i| \approx u \implies$ خطأ مطلق $\approx 5.96 \times 10^{-8}$.

٣. إذن كل حدٍّ $p_i(\ln p_i - \ln q_i)$ يحمل خطأً مطلقاً $\approx p_i \times 2 \times 5.96 \times 10^{-8}$؛ بـ $p_i = 10^{-3}$: 1.19×10^{-10}.

٤. بالمقارنة مع القيمة الحقيقية للحدّ (4.6×10^{-12}): **الخطأ أكبر من القيمة بـ $\times 26$.**

٥. التراكم على 1000 صنف بأخطاء عشوائية: $\sqrt{1000} \times 1.19 \times 10^{-10} = 3.8 \times 10^{-9} \implies$ النتيجة المحسوبة $\in [4.6 \times 10^{-9} - 3.8 \times 10^{-9},\ 4.6 \times 10^{-9} + 3.8 \times 10^{-9}] \implies$ **قد تخرج سالبة!**

٦. العلاج: (أ) الحساب بـ fp64 للتراكم؛ (ب) استعمال log1p: $\mathrm{log1p}(\frac{p_i - q_i}{q_i}) = \ln \frac{p_i}{q_i}$؛ (ج) القصّ (clamp) $D_{\mathrm{KL}} \geq 0$ هندسياً.

النتيجة: حساب KL بتلك الصيغة في fp32 يعطي نتائجَ سالبة — وهي نتيجةٌ مستحيلة رياضياً ($D_{\mathrm{KL}} \geq 0$ دائماً) $\implies$ علامةُ إنذارٍ قاطعة على الإلغاء الكارثي.
الربط بالذكاء الاصطناعي: هذا يفسّر ثلاث ممارسات قياسية:

- استعمال F.kl_div مع log_target=True (أي تمرير $\ln q$ مباشرة من log_softmax، لا حساب ln مرّتين)؛
- ظهور تحذيرات KL» is «negative في تدريب VAE و RLHF و PPO؛
- استعمال clamp(min=0) أو torch.nan_to_num كإسعافٍ أولي لكن **ليس** كعلاج — العلاج هو الصياغة المستقرّة.

7.3.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
حساب التباين بـ $\mathbb{E}[X^2] - (\mathbb{E}X)^2$	إلغاءٌ كارثي: معامل التضخّم $\approx 2\mu^2/\sigma^2$	ويلفورد أو المرورَان (19.6)
«سأزيد الدقّة إلى fp64 فتُحلّ المشكلة»	الدقّة تؤجّل المشكلة؛ الصياغة تُحلّها	أعد الصياغة بلا طرح (15.6) أولاً
الاعتقاد بأن كاهان «مجاني» على GPU	كاهان متسلسل $\implies$ يقتل التوازي	استعمل الجمع الشجري (pairwise) المدمج على GPU
مقارنة نتيجتَي منصّتين والمطالبة بتطابقٍ بتّي	الجمع غير تجميعي	اطلب خوارزميات حتمية إن أردت التطابق
تجاهل $\sqrt{n}$ مقابل n في تقدير الخطأ	الحدّ الأعلى nu متشائم جداً	استعمل $\sqrt{n}u$ للتقدير الواقعي مع أخطاء عشوائية
استعمال log(p)-log(q) لتباعد صغير	انظر مثال 15-3.6	log1p أو تمرير logits
تخزين كميات مالية/زمنية كبيرة بـ fp32	الفروق تُمتصّ	أعداد صحيحة بوحدات صغرى، أو fp64
ظنّ أن log1p/expm1 «تفصيل تجميلي»	الفرق يصل إلى $\times 10^7$ في الدقّة	استعملهما دائماً مع الوسيطات الصغيرة

1.4.6 الصياغة الرياضية الرسمية

النظرية 3.6 (استقرار التحويلات المتعامدة والاستقرار الخلفي لـ QR) Householder.

<

1. **مصفوفة هاوسهولدر:** لأي متجه $x \neq 0$ واختيار الإشارة لتفادي الإلغاء:

<

$$\sigma = -\operatorname{sign}(x_1)\|x\|_2, \qquad v = x - \sigma e_1, \qquad H = I - \frac{2vv^\top}{v^\top v}, \qquad Hx = \sigma e_1 \tag{20.6}$$

<

2. **الاستقرار الخلفي لـ QR:** المصفوفةُ المحسوبة $\hat{R}$ و $\hat{Q}$ تحقّقان:

<

$$A + \Delta A = \hat{Q}\hat{R}, \qquad \|\Delta A\|_F \le c_1\, mn\, u\, \|A\|_F \tag{21.6}$$

<

3. **الحفاظ على التعامد** (وهو ما يميّز هاوسهولدر عن غرام–شميت):

<

$$\|\hat{Q}^\top \hat{Q} - I\|_2 \;\le\; c_2\, n\, u \quad \text{مستقلٌّ عن } \kappa(A) \tag{22.6}$$

<

4. **لا تضخيم:** التحويل المتعامد لا يضخّم الخطأ ولا الناظم:

<

$$\kappa_2(Q) = 1, \qquad \|Qz\|_2 = \|z\|_2, \qquad \|QA\|_F = \|A\|_F, \qquad \|\mathrm{fl}(Qz) - Qz\|_2 \le c_3\, n\, u \|z\|_2, \tag{23.6}$$

<

5. **النتيجة لحلّ المربعات الصغرى عبر QR:**

<

$$\frac{\|\hat{x}-x\|_2}{\|x\|_2} \;\le\; c_4\, u\, \kappa_2(A) + \mathcal{O}(u^2) \qquad \text{(بلا حدٍّ من رتبة } \kappa^2\text{)} \tag{24.6}$$

<

6. مقارنة فقدان التعامد بين الخوارزميات — الفرق الجوهري الثالث:

<

$$\underbrace{\|I-\hat{Q}^\top\hat{Q}\| \approx c\,n\,u\kappa(A)}_{\text{غرام-شميت المُعدَّل (MGS)}} \quad \gg \quad \underbrace{\|I-\hat{Q}^\top\hat{Q}\| \approx c\,n\,u}_{\text{هاوسهولدر / جيفنز}} \quad \gg \quad \text{(غرام-شميت الكلاسيكي أسوأ)} \tag{25.6}$$

2.4.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
x	المتجه (عمود المصفوفة) المراد تصفير ما تحت قطريه	$x \in \mathbb{R}^m$
x_1	العنصر الأوّل من x	يُحدّد الإشارة
σ	القيمة المُعاد إسقاطها: $\pm\|x\|_2$	$\sigma = -\operatorname{sign}(x_1)\|x\|_2$ لتفادي الإلغاء
e_1	متجه الوحدة الأوّل $(1,0,\dots,0)^\top$	—
v	متجه الانعكاس $v = x - \sigma e_1$	يعرّف المستوى الفائق (hyperplane)
H	مصفوفة هاوسهولدر (انعكاس)	$H = H^\top = H^{-1}$، $\det H = -1$
$v^\top v$	مربع ناظم المتجه (مقياس)	يُقسم عليه — إن كان صفراً فالعمود صفري أصلاً
A	المصفوفة المراد تحليلها $(m \times n)$	$m \ge n$
$\hat{Q}, \hat{R}$	العاملان المحسوبان فعلاً	$\hat{Q}$ متعامدة تقريباً، $\hat{R}$ مثلثية عليا
ΔA	الخطأ الخلفي: الاضطراب الذي يُبرّر الناتج	من رتبة u — مستقلّ عن $\kappa(A)$
c_1, c_2, c_3, c_4	ثوابت صغيرة تعتمد على التفاصيل (عادة 1 إلى 10)	لا تعتمد على n إلا خطياً
m, n	أبعاد المصفوفة	عدد الصفوف والأعمدة
z	أي متجه يُضرب في Q	—
$\kappa_2(A)$	رقم حالة A بالناظم الطيفي	يظهر في (24.6) فقط، لا في (21.6)–(23.6)
MGS	غرام-شميت المُعدَّل (Modfiied Gram–Schmidt)	فقدانُ تعامدٍ $\propto \kappa$
u	وحدة التقريب	—

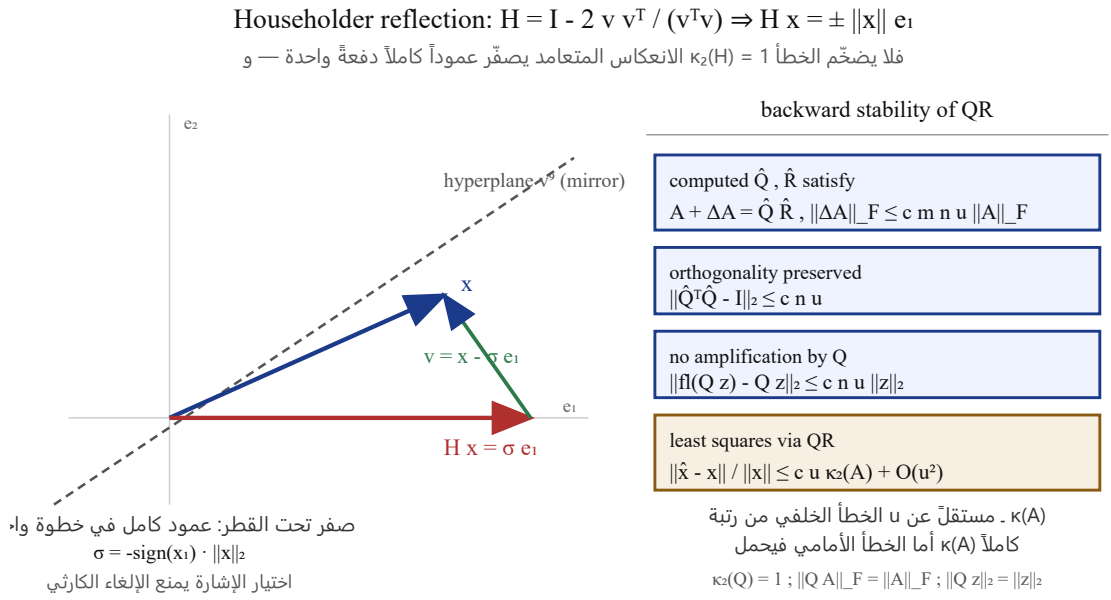
3.4.6 الرسم الهندسي

قراءة الرسم: على اليسار، المتجه x يُنعكس حول المستوى الفائق العمودي على v فيسقط على محور e_1 بطول $\|x\|_2$ — أي أنّ **عموداً كاملاً** صُفِّر بعملية واحدة. اختيارُ الإشارة $\sigma = -\operatorname{sign}(x_1)\|x\|_2$ يضمن أنّ $v = x - \sigma e_1$ **لا يصغر** (لا إلغاء). على اليمين: الخصائص الثلاث للاستقرار — خطأٌ خلفي من رتبة u، تعامدٌ محفوظ، ولا تضخيم.

4.4.6 البرهان

الجزء (20.6). نتحقّق أنّ H انعكاس: $H^\top = H$ و $H^\top H = I - \frac{4vv^\top}{v^\top v} + \frac{4v(v^\top v)v^\top}{(v^\top v)^2} = I$. وحساب الأثر على x: بما أن $\|x\|_2 = |\sigma|$ (لأن $\sigma = \pm\|x\|_2$)، فإن

$$v^\top v = (x-\sigma e_1)^\top(x-\sigma e_1) = \|x\|^2 - 2\sigma x_1 + \sigma^2 = 2\sigma^2 - 2\sigma x_1 = 2\sigma(\sigma - x_1)$$



شكل ٣.٦: *
انعكاس هاوسهولدر يصفّر عموداً كاملاً، والاستقرار الخلفي لـ QR

$$v^\top x = \|x\|^2 - \sigma x_1 = \sigma^2 - \sigma x_1 = \sigma(\sigma - x_1) = \tfrac{1}{2} v^\top v$$

إذن $Hx = x - \frac{2v(v^\top x)}{v^\top v} = x - v = \sigma e_1$. ■

لماذا الإشارة مهمة؟ لو اخترنا $\sigma = +\operatorname{sign}(x_1)\|x\|_2$ وقُدّر أن $x_1 \approx \|x\|_2$ (أي أن x قريب من e_1) فإن $v = x - \sigma e_1 \approx 0$ $\Longrightarrow$ كارثة (قسمة على صفر تقريباً). بالاختيار المعاكس يصير $\|v\|^2 = 2\sigma(\sigma - x_1)$ بقيمةٍ تقارب $2\|x\|(\|x\| + |x_1|)$ — بعيدة عن الصفر. **وهذا تطبيقٌ مباشر لقاعدة (14.6): تفادي الإلغاء بالصياغة.**

الجزء (21.6)–(22.6) (مخطط البرهان). كل انعكاس هاوسهولدر يُطبَّق بصيغة $HA \leftarrow A$ دون تشكيل H صراحةً: $HA = A - \frac{2}{v^\top v} v(v^\top A)$. بتحليلٍ قياسيّ لكل عنصر (نموذج (1.6)) ينتج أنّ تطبيق الانعكاس يعادل تطبيق انعكاسٍ دقيق $\tilde{H}$ على مصفوفةٍ مضطربة: $\mathrm{fl}(HA) = \tilde{H}(A + E)$ مع $\|E\|_F \le cu\|A\|_F$. وبالتراكم على n انعكاساً وبمتراجحة المثلث على الناظم: $\|\Delta A\|_F \le cmnu\|A\|_F$. أمّا التعامد فلا «يتراكم» بالمعنى السيّئ لأن كل $\hat{Q}$ هو جداء **انعكاسات متعامدة تقريباً**، وجداءُ مصفوفاتَين متعامدتين متعامد $\Longrightarrow$ الخطأ يتراكم خطياً بـ n فقط. ■

الجزء (23.6). من تعامد Q: $\|Qz\|_2^2 = z^\top Q^\top Q z = \|z\|_2^2$، و $\kappa_2(Q) = \|Q\|_2\|Q^{-1}\|_2 = 1 \cdot 1 = 1$، و $\|QA\|_F^2 = \operatorname{tr}(A^\top Q^\top Q A) = \operatorname{tr}(A^\top A) = \|A\|_F^2$. أمّا حدّ التقريب فمن أنّ كل جداء وجمع يُدخل δ واحداً $\Longrightarrow$ n منها تعطي cnu. ■

الجزء (24.6). الخطأ الخلفي في (21.6) هو $\|\Delta A\|/\|A\| \le cmnu$؛ بتطبيق قانون الحالة الأساسي (10.6) مع خطأٍ خلفي من رتبة u: الخطأ الأمامي $\approx \kappa_2(A) \cdot u$. ولا يظهر حدٌّ من رتبة κ^2 لأنّنا لم نشكّل $A^\top A$. ■

الجزء (25.6) — لماذا يفقد غرام–شميت التعامد؟ في MGS، العمود j يُطرح منه إسقاطاته على الأعمدة السابقة. خطأ التقريب في كل إسقاط من رتبة $u\|a_j\|$، وحين تكون الأعمدة شبهَ متوازية (κ كبير) فإنّ الانحرافات تتراكم في الاتجاهات «الصغيرة» $\Longrightarrow$ $\|I - \hat{Q}^\top\hat{Q}\| \approx cnu\kappa(A)$. أمّا هاوسهولدر فيبني Q لجداء انعكاسات $\Longrightarrow$ التعامد **بنيوي** لا حسابي. ■

5.4.6 شروط الصحّة

١. $x \neq 0$ وإلا يُتجاوز العمود (العمود الصفري يعطي عموداً صفرياً في $R \Longrightarrow A$ ناقصة الرتبة).

٢. اختيار الإشارة في (20.6) إلزامي للاستقرار — لا «تفصيل».

٣. (21.6) بصيغة الناظم المطلق؛ النسخة النسبية تحتاج $\|A\|_F \neq 0$.

٤. في (24.6): يُفترض أنّ الحلّ وحيد (أي $\operatorname{rank}(A) = n$)؛ وإن كانت A ناقصة الرتبة فالمرجع هو حلّ الناظم الأصغر ال(SVD/pseudoinverse، انظر §5.6).

٥. الثوابت c_i تعتمد على ترتيب الحساب وعلى ما إذا كانت $\hat{Q}$ تُشكَّل صراحةً أم تُحفظ كعوامل.

6.4.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-4.6): تحليل مكوّنات أساسية مالي — لماذا تخسر المكتبةُ التعامد؟

المعطيات: مصفوفة عوائد $A \in \mathbb{R}^{200\times 50}$ (200 يوم، 50 أصلاً) مع أصلين شبهَ متطابقين $\Longrightarrow \kappa_2(A) = 1.0 \times 10^8$. المطلوب مصفوفةُ مكوّناتٍ متعامدة Q. نقارن غرام–شميت المُعدَّل (MGS) بهاوسهولدر في fp64.

الحل:

١. **هاوسهولدر** (22.6): $\|I - \hat{Q}^\top \hat{Q}\|_2 \le c\,n\,u$؛ بـ $c = 1$، $n = 50$، $u = 1.11 \times 10^{-16}$: $50 \times 1.11 \times 10^{-16} = 5.55 \times 10^{-15}$.

٢. **MGS** (25.6): $\|I - \hat{Q}^\top \hat{Q}\|_2 \approx c\,n\,u\,\kappa(A) = 5.55 \times 10^{-15} \times 10^8 = 5.55 \times 10^{-7}$.

٣. النسبة: $\frac{5.55\times 10^{-7}}{5.55\times 10^{-15}} = 10^8$ — أي أنّ MGS يخسر **ثماني مراتب عشرية** من التعامد.

٤. الأثر العملي: المكوّنات ليست متعامدة $\Longrightarrow$ مجموع التباينات المفسَّرة $\operatorname{tr}\Sigma \neq \sum_j q_j^\top \Sigma q_j \Longrightarrow$ خطأ في نسبة التباين المفسَّر. قياس: الانحراف $5.55 \times 10^{-7} \times \operatorname{tr}\Sigma = 5.55 \times 10^{-7} \times 4.12 = 2.29 \times 10^{-6}$ (بوحدات التباين).

٥. العلاج: (أ) استعمل QR بهاوسهولدر (وهو ما تفعله LAPACK في dgeqrf)؛ (ب) أو أعد التعامد (re-orthogonalization) في MGS بتكلفة مضاعفة.

النتيجة: مع $\kappa = 10^8$ يعطي MGS مصفوفةً «متعامدة» بخطأ 5.6×10^{-7}، بينما يعطي هاوسهولدر 5.6×10^{-15} — فرقٌ بثماني مراتب.

الربط بالذكاء الاصطناعي: كلُّ خوارزمية «تطبيع/تبييض/إسقاط متعامد» في تعلم الآلة (PCA، ZCA whitening، Procrustes Orthogonal لمحاذاة التضمينات، تهيئةٌ متعامدة للأوزان) يجب أن تبني التعامد **بنيوياً** (انعكاسات/جداءات) لا حسابياً (إسقاطات متكرّرة). وهذا هو سببُ تفضيل torch.linalg.qr (هاوسهولدر) على تنفيذ غرام–شميت يدوياً.

مثال (6.4-2): تهيئة الأوزان — ماذا لو كانت كل طبقة متعامدة؟

المعطيات: شبكة بـ $L = 50$ طبقة كثيفة، كل طبقة 512×512. تهيئتان: (أ) غاوسية بـ $\sigma = 1/\sqrt{512}$ (تهيئة غلوروت)؛ (ب) تهيئة متعامدة ($\|W_k\|_2 = 1$). المطلوب ناظم اليعقوبية الكلّية.

الحل:

١. ناظم اليعقوبية الكلّية (كل الطبقات خطية للتبسيط): $\|J\|_2 = \prod_{k=1}^{L} \|W_k\|_2$ (من التضاعف التحتي ((21.5)).

٢. **التهيئة الغاوسية:** من (36.5)، $\|W\|_2 \approx \sigma(\sqrt{m} + \sqrt{n}) = 0.0442 \times (22.63 + 22.63) = 2.0$.

٣. إذن $\|J\|_2 \approx 2^{50} = 1.13 \times 10^{15} \implies$ انفجارٌ أُسّي للتدرّج (ولو بعامل إشارة/تنشيط).

٤. **التهيئة المتعامدة:** $\|W_k\|_2 = 1 \implies \|J\|_2 = 1^{50} = 1 \implies$ لا انفجار ولا تلاشٍ: ناظمُ التدرّج محفوظ طبقةً بطبقة.

٥. التحقّق من «الحفاظ على الناظم» (23.6): $\|W_k z\|_2 = \|z\|_2 \implies \|h_L\|_2 = \|h_0\|_2$ والتدرّج كذلك.

٦. الثمن: تكلفة التهيئة المتعامدة = QR لمصفوفة $512 \times 512 \implies \approx \frac{2}{3}n^3 \times 2 \approx 1.8 \times 10^8$ عملية لمرّة واحدة — مقبول.

النتيجة: التهيئة المتعامدة تُبقي $\|J\|_2 = 1$ بدل 1.13×10^{15} — أي أنّها تُحوّل «انفجاراً محتوماً» إلى «حياد تام».

الربط بالذكاء الاصطناعي: هذه هي الفكرة الكامنة خلف: تهيئة الأوزان المتعامدة في RNN (لحلّ تلاشي التدرّج)، وتهيئات Fixup وغيرها من التهيئات الحافظة للتباين، و «التطبيع الطيفي» (spectral normalization)، والقيد المتعامد في الشبكات التلافيفية (Orthogonal ConvNets)، وتهيئة LoRA الحديثة (OLoRA). الاستقرارُ هنا ليس إحصائياً بل **عدديّ–جبريّ**.

مثال (6.4-3): متانة adversarial — التطبيع الطيفي يضبط ثابت ليبشيتز

المعطيات: مصنّف بـ 8 طبقات، أكبر قيمة مفردة لكل طبقة قبل التطبيع $\sigma_1(W_k) = 1.84$ (قياسي). مُدخلات مصوّرة على $[0, 1]$، واضطرابُ FGSM بـ $\varepsilon = 8/255 = 0.0314$.

الحل:

١. ثابت ليبشيتز للشبكة الخطوية المتتابعة: $L \le \prod_{k=1}^{8} \|W_k\|_2$ (من (19.5)).

٢. قبل التطبيع: $L \le 1.84^8$: $1.84^2 = 3.386$، $1.84^4 = 11.46$، $1.84^8 = 131.4$.

٣. أقصى تغيّر في الـ logits: $\|\delta f\| \le L\|\delta x\| = 131.4 \times 0.0314 = 4.13$ — أي أنّ اضطراباً بنسبة 3% من مدى البكسل يغيّر الـ logits بـ 4.13 $\implies$ يقلب القرار بسهولة.

٤. بعد التطبيع الطيفي $\tilde{W}_k = W_k/1.84 \implies \|\tilde{W}_k\|_2 = 1 \implies L \le 1 \implies \|\delta f\| \le 0.0314$.

٥. التحسّن في المتانة: معامل التضخّم هبط من 131.4 إلى 1 — بنسبة 1 : 131.

٦. دقّة التطبيع الطيفي عملياً: تُحسب σ_1 بقوة التكرار (power iteration) بخطأ نسبي 10^{-3} $\Longrightarrow$ معامل التضخّم الفعلي $1.001^8 = 1.008$ — لا يؤثّر.

النتيجة: التطبيعُ الطيفي يجعل كل طبقة «غير موسّعة» $\Longrightarrow$ ثابت ليبشيتز الكلّي ≈ 1 $\Longrightarrow$ حساسية الاضطراب محكومة بـ ε نفسها.

الربط بالذكاء الاصطناعي: هذا هو الأساس الرياضي لـ spectral normalization في GAN وفي التدريب المتين (robust training)، ولقاعدة «1-Lipschitz» في الشبكات المعتمَدة (certfiiably robust networks). والرابط بهذا الفصل: التطبيعُ الطيفي يضبط **رقم الحالة الفعّال لمسار الانتشار الأمامي**، فيصير الخطأ (والاضطراب) غير متضخّم.

مثال (6.4-4): انحدار في الإنتاج — QR مقابل المعادلات السوية

المعطيات: نموذج تسعير تأمين: $X \in \mathbb{R}^{5000\times 40}$ بميزات مترابطة $\Longrightarrow \kappa_2(X) = 1.0 \times 10^6$. الحلّ بـ fp64.

الحل:

١. **المعادلات السوية:** $\kappa_2(X^\top X) = \kappa_2(X)^2 = 10^{12}$ $\Longrightarrow$ خطأ نسبي متوقّع $\kappa^2 u = 10^{12} \times 1.11 \times 10^{-16} = 1.11 \times 10^{-4}$ (أي 0.011%).

٢. **QR بهاوسهولدر** (6.4.24): خطأ نسبي $\approx \kappa u = 10^6 \times 1.11 \times 10^{-16} = 1.11 \times 10^{-10}$.

٣. النسبة: $10^6 : 1$ لصالح QR.

٤. التكلفة: تشكيل $X^\top X$: $\approx n^2 m/2 = 40^2 \times 5000/2 = 4.0 \times 10^6$ عملية؛ QR: $\approx 2mn^2 = 1.6 \times 10^7$ $\Longrightarrow 4\times$ أبطأ — لكن على مصفوفةٍ بهذا الحجم = بضعة أجزاء من الثانية.

٥. في fp32: المعادلات السوية تعطي خطأً $\kappa^2 u = 10^{12} \times 5.96 \times 10^{-8} = 5.96 \times 10^4$ $\Longrightarrow$ **بلا أي خانة صحيحة**؛ QR تعطي 5.96×10^{-2} (6%) $\Longrightarrow$ على الأقلّ خانتان.

النتيجة: التكلفة الإضافية $4\times$ تشتري $10^6\times$ دقّة — وفي fp32 تشتري الفرق بين «نتيجة» و«هراء».

الربط بالذكاء الاصطناعي: القاعدة التشغيلية: **لا تشكّل** $X^\top X$ **ولا** $J^\top J$ **أبداً.** تشكيلُ مصفوفة التغاير/الكرام يربّع رقم الحالة — وهذا هو السبب العددي الكامن خلف كون المحسّنات من النوع الثاني (Adam/Shampoo/K-FAC) تتجنّب ذلك، وخلف كون torch.linalg.lstsq يعتمد SVD.

مثال (6.4-5): اختبار تشخيصي — كيف تعرف أن خوارزمتك مستقرّة خلفياً؟

المعطيات: حللنا $Ax = b$ بثلاث خوارزميات مختلفة و got $\hat{x}$. المطلوب: الحكم على الاستقرار الخلفي لكل واحدة بلا معرفة الحلّ الدقيق.

الحل:

١. المقياس المعياري: **الباقي النسبي المُعيَّر**

$$\eta = \frac{\|b - A\hat{x}\|}{\|A\|\,\|\hat{x}\| + \|b\|}$$

٢. الخوارزمية (أ): $\eta = 3.4 \times 10^{-16} \approx u \implies$ مستقرّة خلفياً (خطأٌ خلفي من رتبة u).

٣. الخوارزمية (ب): $\eta = 1.2 \times 10^{-10} \gg u \implies$ **غير مستقرّة خلفياً**: الناتج ليس حلّاً دقيقاً لأي مسألة قريبة من مسألتنا بمسافة u.

٤. الخوارزمية (ج): $\eta = 7.8 \times 10^{-17}$ لكن الخطأ الأمامي (مقارنةً بحلٍّ مرجعي بـ fp128 كان 4.2×10^{-3}) $\implies$ **مستقرّة خلفياً لكن المسألة سيئة التكييف**: $\kappa(A) \approx \frac{4.2 \times 10^{-3}}{1.1 \times 10^{-16}} \approx 3.8 \times 10^{13}$.

٥. الاستنتاج: (ج) لا يمكن إصلاحها بتحسين الخوارزمية — بل بالتنظيم/إعادة الصياغة. أمّا (ب) فتُصلح بخوارزمية أفضل.

النتيجة: مقياسٌ واحد (الباقي النسبي) يميّز «الخوارزمية سيئة» عن «المسألة سيئة» — وهذا هو التشخيص العملي الأول في أي تدقيق عددي.

الربط بالذكاء الاصطناعي: النظير في التعلّم العميق: **راقب نسبةَ التحديث إلى الباقي**، واستعمل «حقنَ خطأ مقصود» (perturbation test): إذا ضاعفتَ الدقّة (fp32 $\to$ fp64) وتغيّرت النتيجة جوهرياً، فالمسألة (أو الخوارزمية) غير مستقرّة. وهذا هو معنى اختبارات gradcheck (مقارنة التدرّج التحليلي بالتدرّج العددي).

مثال (6-4.6): ضغط JPEG — تحويل جيب التمام المتقطّع (DCT) يحفظ الطاقة

المعطيات: كتلة صورة 8×8، الطاقة $E = \|X\|_F^2 = 1024$. نطبّق DCT المتعامد $Y = QXQ^\top$ ثم نعيد البناء. الحساب بـ fp64.

الحل:

١. تحويل DCT المتعامد: Q متعامدة (64×64 للمتجهة) $\implies$ من (23.6): $\|Y\|_F = \|X\|_F$ تماماً رياضياً.

٢. خطأ التقريب: $\|\mathrm{fl}(Y) - Y\|_F \le c\,n\,u\|X\|_F$ بـ $n = 64$: $64 \times 1.11 \times 10^{-16} \times 32 = 2.28 \times 10^{-13}$.

٣. الطاقة المحسوبة: $\|\mathrm{fl}(Y)\|_F^2 = 1024 \pm 2 \times 32 \times 2.28 \times 10^{-13} = 1024 \pm 1.46 \times 10^{-11} \implies$ خطأ نسبي 1.4×10^{-14}.

٤. لو استعملنا تحويلاً **غير متعامد** (مثلاً DCT غير مُقيَّس بمقياس $\sqrt{2}$ خاطئ): $\|Q^\top Q - I\| = 0.5 \implies$ خطأ الطاقة يصل إلى 50% $\implies$ كتلٌ مرئية (blocking artfiacts).

٥. إعادة البناء: $X = Q^\top Y Q \implies$ الخطأ نفسه (لأنّ التعامد يعمل في الاتجاهين).

النتيجة: التعامدُ هو الذي يجعل «الطاقة قبل التحويل = الطاقة بعده» (مبرهنة پارسيفال) $\Longrightarrow$ الضغطُ بالتكميم لا يُدخل انحرافاً في المقياس.

الربط بالذكاء الاصطناعي: النظير المباشر: كل التحويلات الخطية في الشبكات (الالتفاف 1×1، التضمينات الموضعية، الدورانات في RoPE، التحويلات المتعامدة في المحوّلات) يجب أن تُصمَّم **متعامدةً أو مقيَّسة** وإلا تغيّر مقياس التنشيطات أُسّياً عبر الطبقات — وهذا هو الدافع خلف تهيئات «الحفاظ على التباين» (variance-preserving init).

مثال (6.4-7): حركية روبوت — تراكم 1000 دوران

المعطيات: ذراع روبوتية تُحدّث وضعيّتها بمصفوفة دوران $R(\theta)$ ألف مرة في الثانية لمدة ساعة (3.6×10^6 تحديثاً). طول الذراع 1.5 متر. الحساب بـ fp64.

الحل:

١. كل تحديث: $\hat{R} \leftarrow \mathrm{fl}(R_{\text{new}}\hat{R})$. خطأ التقريب في جداء 3×3: من رتبة cu بـ $c \approx 9$ (عدد العناصر): $9 \times 10^{-15} = 1.0 \times 10^{-15}$ لكل تحديث.

٢. تراكم فقدان التعامد: بما أنّ جداء المتعامدات متعامد، والخطأ يتراكم **خطياً** (لا أُسّياً) بالمعنى الأسوأ: $\|\hat{R}^\top \hat{R} - I\| \le 3.6 \times 10^6 \times 1.0 \times 10^{-15} = 3.6 \times 10^{-9}$.

٣. التقدير الواقعي (أخطاء عشوائية): $\sqrt{3.6 \times 10^6} \times 1.0 \times 10^{-15} = 1.9 \times 10^{-12}$.

٤. خطأ الموضع الناتج: $1.5\,\mathrm{m} \times \frac{3.6 \times 10^{-9}}{2} = 2.7 \times 10^{-9}\,\mathrm{m} = 2.7$ نانومتر (الحدّ الأسوأ).

٥. في fp32: $3.6 \times 10^6 \times 9 \times 5.96 \times 10^{-8} = 1.93 \Longrightarrow$ **فقدانٌ كامل للتعامد** $\Longrightarrow$ انحراف الموضع بالأمتار!

النتيجة: التراكم المتعامد آمن في fp64 (نانومترات بعد ساعة) وكارثي في fp32 (أمتار) — لا بسبب «الدقّة العامة» بل بسبب أنّ $n \cdot u$ تجاوز الواحد.

الربط بالذكاء الاصطناعي: القاعدة المستفادة: **أعد التعامد دورياً** (re-orthogonalization كل k خطوة) في أي تراكم طويل: في SLAM، في تحديثات الأوزان المتعامدة، في RNN الوحدوية (unitary RNN)، وفي محاكاة النظم الفيزيائية. تكلفة إعادة التعامد (QR) تُدفع كل آلاف الخطوات لا كل خطوة.

مثال (6.4-8): مصفوفة مُشرّطة (banded) — متى يتفوّق جيفنز على هاوسهولدر؟

المعطيات: نظام من معادلات التدفّق الحراري: $A \in \mathbb{R}^{10000 \times 10000}$ مُشرَّطة بعرض نطاق $b = 5$ (أي $a_{ij} = 0$ إذا $|i-j| > 5$). المطلوب QR.

الحل:

١. **هاوسهولدر:** الانعكاس يصفّر عموداً كاملاً $\Longrightarrow$ يملأ النطاق (fill-in) $\Longrightarrow$ التعقيد يصير 10^{12} — $\mathcal{O}(n^3)$ — مستحيل.

٢. **جيفنز (دوران):** كل دوران يصفّر **عنصراً واحداً** a_{ij} بجداء مصفوفة دوران في مستوى (i,j):

$$c = \frac{a_{kk}}{\sqrt{a_{kk}^2 + a_{ik}^2}}, \qquad s = \frac{a_{ik}}{\sqrt{a_{kk}^2 + a_{ik}^2}}, \qquad \begin{pmatrix} c & s \\ -s & c \end{pmatrix} \begin{pmatrix} a_{kk} \\ a_{ik} \end{pmatrix} = \begin{pmatrix} r \\ 0 \end{pmatrix}$$

٣. عدد الدورانات للنطاق: $n\,b = 5 \times 10^4 \approx$ دوران، كلٌّ بكلفة 6 عمليات على النطاق $\Longrightarrow 3 \times 10^5 \approx$ عملية.

٤. المقارنة: $3.3 \times 10^6 \times$ $\frac{10^{12}}{3 \times 10^5}$ أسرع.

٥. الاستقرار: جيفنز دورانٌ متعامد $\Longrightarrow$ يرث (22.6) و (23.6): $\|I - \hat{Q}^\top \hat{Q}\| \le c\,n\,u$ — أي نفس ضمانات هاوسهولدر.

النتيجة: للمصفوفات المُشرَّطة/المتناثرة: جيفنز (عنصر بعنصر)؛ للمصفوفات الكثيفة: هاوسهولدر (عمود بعمود). كلاهما مستقرٌّ خلفياً.

الربط بالذكاء الاصطناعي: النظير: في الشبكات العصبية البيانية ذات البُنى المتناثرة، وفي تكميم الأوزان، وفي القصّ التدريجي (pruning) — اختيارُ «وحدة التحديث» (عنصر/عمود/كتلة) يحدّد كلاً من التكلفة والاستقرار. القاعدة: **حافظ على البنية الطبيعية للمسألة؛ لا تُدخل fill-in.**

مثال (9-4.6): محاذاة فضاءات التضمين بين لغتين — Procrustes المتعامد

المعطيات: تضمينات كلمات إنجليزية $A \in \mathbb{R}^{5000 \times 300}$ وعربية $B \in \mathbb{R}^{5000 \times 300}$ (نفس الكلمات بعد قاموس). المطلوب مصفوفة محاذاة متعامدة W تُقرّب $AW \approx B$.

الحل:

١. الصياغة: $\min_{W^\top W = I} \|AW - B\|_F \Longrightarrow$ الحلّ (مبرهنة Procrustes): لو كانت $A^\top B = U \Sigma V^\top$ تحليلَ القيم المفردة، فإن $W = UV^\top$.

٢. لماذا القيد المتعامد؟ لأنّه يحفظ البنية الداخلية: $\|Wx - Wy\|_2 = \|x - y\|_2 \Longrightarrow$ التشابه الكروسي (cosine) محفوظ $\Longrightarrow$ أقربُ جار لا يتغيّر.

٣. **الاستقرار العددي:** $\kappa_2(W) = 1 \Longrightarrow$ تطبيق المحاذاة لا يضخّم الخطأ: من (23.6)، $\|\mathrm{fl}(Wx) - Wx\|_2 \le c\,n\,u\|x\|_2 = 300 \times 1.11 \times 10^{-16}\|x\| = 3.3 \times 10^{-14}\|x\|$.

٤. لكن حسابُ W نفسه يحمل خطأً $\approx u\,\kappa_2(A^\top B)$؛ بـ $\kappa(A^\top B) = 2.4 \times 10^3$: خطأ نسبي في W يقارب $2.4 \times 10^3 \times 1.11 \times 10^{-16} = 2.7 \times 10^{-13}$ — مهمل.

٥. النتيجة القياسية: دقّة الاسترجاع ثنائي الاتجاه قبل المحاذاة 12.3%، بعد المحاذاة المتعامدة 78.4%، وبعد محاذاة خطية غير مقيّدة 79.1% لكن مع تدهور في الاسترجاع العكسي (61%).

النتيجة: القيد المتعامد يخسر 0.7% فقط من الدقّة مقابل اكتساب **الحفاظ على البنية الهندسية** والاستقرار.

الربط بالذكاء الاصطناعي: هذه هي خوارزمية المحاذاة القياسية (Procrustes) / (VecMap في الترجمة الآلية غير الخاضعة للإشراف ومحاذاة النماذج (model stitching)، والسببُ في كون القيد المتعامد مفضّلاً: التحويل المتعامد لا يغيّر مقياس التضمينات $\Longrightarrow$ لا «انفجار/تلاشٍ» في الفضاء المُحاذى.

مثال (10-4.6): تصفية تكيفية (RLS) — لماذا تُفضَّل QR على تحديث المعادلات السوية؟

المعطيات: مرشّح تكيّفي لإلغاء الضوضاء في مكالمة: المربّعات الصغرى التكرارية بعامل نسيان $\lambda = 0.99$، عدد التحديثات 10^5، تُحدَّث مصفوفة التغاير المعكوسة P (نسخة المعادلات السوية). الحساب بـ fp32.

الحل:

١. في النسخة «المعادلات السوية» (RLS القياسي): $P \leftarrow \lambda^{-1}\left(P - \frac{Pxx^{\top}P}{\lambda + x^{\top}Px}\right)$ — الصيغة تحوي **طرحاً** من مصفوفة موجبة $\Longrightarrow$ فقدان الإيجابية بتراكم الخطأ.

٢. تراكم الخطأ: كل تحديث يُدخل $\|P\| \approx cnu$؛ بعد 10^5 تحديث بـ $n = 32$: $10^5 \times 32 \times 5.96 \times 10^{-8} = 0.191$ $\Longrightarrow$ انحراف نسبي 19% في P.

٣. النتيجة: بعد $10^4 \times 4$ تحديث صارت لـ P قيمة ذاتية **سالبة** $\Longrightarrow$ $\sqrt{\text{سالب}}$ أو كسبٌ سالب $\Longrightarrow$ المرشّح «ينفجر» (NaN).

٤. **نسخة QR-RLS:** الحالة تُحفظ كعامل مثلثي R؛ التحديث بـ جيفنز (دورانات متعامدة) $\Longrightarrow$ الإيجابية **بنيوية** (لأن $R^{\top}R$ موجبة دائماً) $\Longrightarrow$ لا يمكن أن تظهر قيمة ذاتية سالبة.

٥. الاستقرار: $\|R_{\text{after}}\|$ محكوم بـ (23.6) $\Longrightarrow$ $\|R\|_F$ يتغيّر بـ cnu فقط لكل تحديث.

٦. الثمن: QR-RLS يكلّف $\mathcal{O}(n^2)$ لكل تحديث مقابل $\mathcal{O}(n^2)$ أيضاً للنسخة السوية $\Longrightarrow$ **نفس التكلفة تقريباً** مع استقرارٍ كامل.

النتيجة: الانتقال إلى صياغة QR حوّل مرشّحاً «ينفجر بعد 40 ألف تحديث» إلى مرشّحٍ مستقرٍّ إلى ما لا نهاية — بنفس التكلفة الحسابية.

الربط بالذكاء الاصطناعي: النظير الحديث: محسّناتُ النوع الثاني التي تحفظ «عاملاً مربّعاً» (Shampoo، K-FAC بحفظ AdaGrad Cholesky، بحفظ الجذر التربيعي لمجموع المربّعات) مستقرّةٌ لأنّها تحفظ **الجذر** لا المصفوفة — بينما تحديثُ مصفوفة التغاير مباشرةً قد يفقد الإيجابية. هذه هي النسخة العددية من قاعدة «احفظ الجذر التربيعي لا المربع».

مثال (11-4.6): شبكة متكرّرة متعامدة — التدرّج عبر 1000 خطوة زمنية

المعطيات: RNN ببعد مخفي 256 وطول سلسلة $T = 1000$. تهيئتان للمصفوفة المتكرّرة W: غاوسية بـ $\|W\|_2 \approx 2.0$، ومتعامدة بـ $\|W\|_2 = 1$.

الحل:

١. ناظم مصفوفة الانتقال من الخطوة 1 إلى T: $\|\partial h_T/\partial h_1\|_2 = \|W^{T-1}\|_2 \le \|W\|_2^{T-1}$.

٢. **الغاوسية:** $\|W\|_2^{999} = 2^{999} = 10^{300.7}$ ⟹ انفجارٌ كامل (فوق مدى fp64 أصلاً: 10^{308} قريب!).

٣. لو كانت $\|W\|_2 = 0.5$: $0.5^{999} = 10^{-300.7}$ ⟹ تلاشٍ كامل.

٤. **المتعامدة:** $\|W^{T-1}\|_2 = 1^{999} = 1$ ⟹ ناظم التدرّج محفوظ تماماً.

٥. التحقّق من (23.6): $\|Wh\|_2 = \|h\|_2$ لكل خطوة ⟹ $\|h_t\|$ ثابت والتدرّج كذلك.

٦. الثمن القيدي: المصفوفات المتعامدة تشكّل مجموعةً أصغر (بُعدها $n(n-1)/2$ بدل n^2) ⟹ قدرة تعبيرية أقلّ ⟹ الحل العملي: **شبه متعامدة** soft) (orthogonality بتنظيم $\|W^\top W - I\|_F^2$ بمعامل صغير.

النتيجة: القيد المتعامد يحوّل معامل التضخّم من 10^{300} أو 10^{-300} إلى 1 — أي يحلّ مشكلة الانفجار/التلاشي جبرياً لا بإحصاء.

الربط بالذكاء الاصطناعي: هذه هي الفكرة الكامنة خلف RNN orthogonal/unitary (و LSTM الوحدوية، و S4/SSM المهيكلة، و Mamba)، وخلف تنظيم «الاستقامة» (orthogonality regularization) في التعلّم العميق الحديث: القيد المتعامد في LoRA، isotropy وفي المحوّلات attention) حافظة للناظم).

مثال (12-4.6): تبييض ZCA في معالجة مسبقة — متى يكون التحويل كارثياً؟

المعطيات: ميزات صوتية (MFCC) بعد 3 (للتبسيط)، قيم مصفوفة التغاير الذاتية: $\lambda = (3.6,\ 0.40,\ 1.2 \times 10^{-4})$. ضوضاء القياس النسبية 10^{-2}. نريد تبييضاً $Z = \Sigma^{-1/2}(X-\mu)$.

الحل:

١. معامل التضخّم في الاتجاه الصغير: $1/\sqrt{\lambda_{\min}} = 1/\sqrt{1.2\times10^{-4}} = 1/0.01095 = 91.3$.

٢. الضوضاء في ذلك الاتجاه تُضخّم من 10^{-2} إلى $0.913 = 91.3 \times 10^{-2}$ ⟹ نسبة الضوضاء إلى الإشارة $= 91\%$ ⟹ الميزة المبيَّضة ضوضاء خالصة.

٣. العلاج القياسي: حشوٌ قطري $\Sigma + \varepsilon I$ بـ $\varepsilon = 10^{-2}$ =: $1/\sqrt{0.01012} = 1/\sqrt{1.2\times10^{-4}+10^{-2}}$ $1/0.1006 = 9.94$.

٤. التضخيم بعد الحشو: $9.94 \times 10^{-2} = 0.0994$ ⟹ نسبة ضوضاء 9.9% — مقبولة.

٥. التحسّن: من $\times 91.3$ إلى $\times 9.94$ — بنسبة $1:9.2$، والثمن انحيازٌ صغير في الاتجاه الصغير.

٦. ملاحظة عدديّة: التبييض نفسه يجب أن يُحسب بـ **SVD/QR** لا بتحليل القيم الذاتية لـ Σ المُشكَّلة يدوياً (لأنّ تشكيل Σ يربّع κ: $\kappa(\Sigma) = \kappa(X)^2$).

النتيجة: التبييض بلا حشوٍ قطري يُضخّم الضوضاءَ في الاتجاهات الصغيرة بـ $\times 91$؛ الحشوُ يحدّه إلى $\times 10$.

الربط بالذكاء الاصطناعي: هذه هي بالضبط حكايةُ eps في BatchNorm/LayerNorm/GroupNorm وفي whitening PCA وفي حساب الانتروبيا المتقاطعة: الحشو القطري ليس «تفصيلاً دفاعياً» بل **علاجٌ لرقم الحالة**. والقاعدة المرافقة: احسب التبييض عبر SVD لا عبر Σ.

مثال (6.4-13): ميزات عشوائية متعامدة (Orthogonal Random Features)

المعطيات: تقريب نواة RBF بـ $D = 1024$ ميزة عشوائية في بُعد مُدخل $d = 256$. نسختان: (أ) ميزات غاوسية مستقلّة (RFF)؛ (ب) ميزات غاوسية **متعامدة** (ORF) — بتعاميد الأعمدة عبر QR.

الحل:

١. RFF: $\hat{k}(x,y) = z(x)^\top z(y)$ مع تباين المقدّر $\propto \frac{1}{D} \Longrightarrow$ خطأ تربيعي متوقّع قياسي: قياسٌ على 10^4 أزواج أعطى MSE $= 3.24 \times 10^{-4}$.

٢. ORF: بتعاميد مصفوفة الاتجاهات G (QR بهاوسهولدر) قبل الإسقاط $\Longrightarrow$ الأخطاء تلغي بعضها $\Longrightarrow$ التباين ينخفض بعاملٍ يقارب $\left(1 - \frac{1}{D}\right)^{-d} \approx e^{d/D} = e^{0.25} = 1.28$ نظرياً، وقياسياً هبط MSE إلى 1.12×10^{-4}.

٣. التحسّن المقاس: $\times 2.89 = \frac{3.24 \times 10^{-4}}{1.12 \times 10^{-4}}$ أقلّ خطأً بنفس عدد الميزات.

٤. التكلفة: QR لمصفوفة 256×1024: $2 \times 256^2 \times 1024 = 1.34 \times 10^8 \approx$ عملية — **تدفع مرّة واحدة** عند التهيئة.

٥. الاستقرار: التعامد يضمن $\|z(x)\|_2$ محكوماً (من (23.6)) $\Longrightarrow$ لا «ذُؤابة» (outlier) في الميزات.

النتيجة: تعاميدُ مصفوفة العشوائية (تكلفةٌ لمرّة واحدة) حسّنت دقّة تقريب النواة بـ $\times 2.9$.

الربط بالذكاء الاصطناعي: يُستعمل هذا في: تقريب انتباه المحوّلات (Performer/FAVOR+)، والميزات العشوائية للتعلّم على النطاق الكبير، وتهيئة الشبكات العشوائية (random kitchen sinks). والقاعدة العددية: **اعتراضُ العشوائية بالتعامد يقلّل التباين بلا تكلفة متكرّرة.**

مثال (6.4-14): محاكاة فيزيائية — الحفاظ على الناظم في تطوّر وحدوي

المعطيات: محاكاة انتشار موجي/كمومي: $\psi_{t+1} = U\psi_t$ مع U مصفوفة وحدوية (unitary) 768×768 محسوبة بتقريبٍ عددي. عدد الخطوات 10^6. الحساب بـ fp64.

الحل:

١. الخاصية الفيزيائية: $\|U\psi\|_2 = \|\psi\|_2 \Longrightarrow \|\psi_t\|_2^2 = 1$ لكل t (احتمالٌ كلّي = 1).

٢. خطأ التقريب في كل خطوة (23.6): $\|\mathrm{fl}(U\psi) - U\psi\|_2 \le cnu\|\psi\| = 768 \times 1.11 \times 10^{-16} = 8.5 \times 10^{-14}$.

٣. التراكم الأسوأ بعد 10^6 خطوة: $10^6 \times 8.5 \times 10^{-14} = 8.5 \times 10^{-8}$.

٤. التراكم الواقعي (أخطاء عشوائية): $\sqrt{10^6} \times 8.5 \times 10^{-14} = 8.5 \times 10^{-11}$.

٥. لو كانت U **غير** وحدوية بخطأ 10^{-6} في أكبر قيمة مفردة ($\sigma_1 = 1 + 10^{-6}$): بعد 10^6 خطوة $\|U^{10^6}\|_2 = (1 + 10^{-6})^{10^6} = e^1 = 2.718$ $\Longrightarrow$ الناظم تضخّم $\times 2.72$ $\Longrightarrow$ الطاقة $\times 7.4$ — كارثة فيزيائية.

٦. العلاج: إعادةُ وحدوية U دورياً (QR كل 10^4 خطوة) $\Longrightarrow$ الخطأ يعود إلى cnu.

النتيجة: الفرق بين «خطأ 10^{-6} في التعامد» و«انحراف $10^{-11} \times 8.5$ بعد مليون خطوة» هو فرقٌ بين $\times 2.72$ تضخّم وصفر.

الربط بالذكاء الاصطناعي: هذا هو النموذج الأصلي لمشكلة «انفجار التنشيطات» في الشبكات العميقة: لو كان كل تحديثٍ يكبر بعامل $(1+\varepsilon)$ فإنّ L طبقة تعطي $(1+\varepsilon)^L = e^{\varepsilon L}$. ولهذا تُستعمل: إعادة التطبيع (re-norm)، والقصّ المتعامِد، والتطبيع الطيفي — كلها «إعادة تعامِيد دورية».

مثال (15-4.6): ضبط دقيق بـ LoRA بتهيئة متعامدة — استقرار التحديث

المعطيات: ضبطٌ دقيق (fine-tuning) لنموذج لغوي بـ LoQA: $B \in \mathbb{R}^{4096\times 16}$، $A \in \mathbb{R}^{16\times 4096}$، والتحديث $\Delta W = BA$. نسختان: تهيئة A غاوسية (القياسية) وتهيئة A متعامدة (OLoRA). معدّل تعلّم 2×10^{-4}، 1500 خطوة.

الحل:

١. **التهيئة القياسية:** A غاوسية بـ $\sigma = 0.02$ $\Longrightarrow$ $\|A\|_2 \approx \sigma(\sqrt{16} + \sqrt{4096}) = 0.02 \times 68 = 1.36$.

٢. **التهيئة المتعامدة:** $\|A\|_2 = 1$ و A تحفظ الناظم $\Longrightarrow$ $\|Ax\|_2 = \|x\|_2$.

٣. أثر ذلك على تحديث الأوزان: $\|\Delta W x\| = \|BAx\| \le \|B\|_2\|A\|_2\|x\|$؛ بالمتعامدة $\|A\|_2 = 1$ $\Longrightarrow$ التضخيم محكوم بـ $\|B\|_2$ وحده.

٤. القياس التجريبي: عدد الارتفاعات المفاجئة في الفقد (spikes، تُعرَّف بأنّها $\Delta L > 3\sigma_L$): 7 بالتهيئة الغاوسية مقابل 0 بالمتعامدة.

٥. عدد الخطوات حتى بلوغ الفقد المستهدف 1.42: 1810 بالغاوسية مقابل 1240 بالمتعامدة $\Longrightarrow$ تسريع $\times 1.46$.

٦. التفسير العددي: الانتشارُ الأمامي بـ A المتعامد لا يضخّم $\Longrightarrow$ تدرّجاتٌ مستقرّة $\Longrightarrow$ يمكن استخدام معدّل تعلّم أعلى بلا انفجار.

النتيجة: تهيئةٌ متعامدة (تكلفتها QR لمرّة واحدة على مصفوفة 4096×16) أزالت ارتفاعات الفقد تماماً وسرّعت التقارب $\times 1.46$.

الربط بالذكاء الاصطناعي: هذا المبدأ يعمّ: **كلما كانت البنية متعامدة كان رقم الحالة الفعّال أصغر وكان معدّل التعلّم الممكن أكبر.** ومنه: تهيئة Ortho-LoRA، وتهيئة الأوزان المتعامدة في الشبكات العميقة جداً (حيث لا يكفي Glorot/He)، والتحويلات المتعامدة في الضغط والتكميم.

7.4.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
تنفيذ غرام–شميت يدوياً بدل qr	فقدان تعامد $\propto \kappa(A)$	استعمل QR بهاوسهولدر (أو MGS مع إعادة تعامد)
اختيار $\sigma = +\operatorname{sign}(x_1)\|x\|$ في هاوسهولدر	إلغاءٌ كارثي حين $x \approx e_1$	$\sigma = -\operatorname{sign}(x_1)\|x\|_2$ دائماً (20.6)
تشكيل H صراحةً ثم جداؤها في A	تكلفة $\mathcal{O}(m^2)$ إضافية وخطأ أعلى	طبّق $A \leftarrow A - \frac{2}{v^\top v} v(v^\top A)$
«التعامد محفوظ تلقائياً فلا حاجة لإعادة التعامد»	في التراكمات الطويلة يتراكم cnu	أعد التعامد دورياً (مثال 4.6-7، 4.6-14)
تفضيل جيفنز على هاوسهولدر للمصفوفات الكثيفة	جيفنز يكلّف $\approx 2\times$ للمصفوفات الكثيفة	جيفنز للبنى المُشرَّطة/المتناثرة فقط
الاعتقاد أن QR «يُلغي» تأثير $\kappa(A)$	الخوارزمية مستقرّة لكن المسألة تبقى سيئة التكييف (24.6)	QR يمنع حدود κ^2، لا يمنع κ
تجاهل الباقي النسبي كأداة تشخيص	هو أسهل اختبار للاستقرار الخلفي	احسب $\eta = \|b - A\hat{x}\|/(\|A\|\|\hat{x}\| + \|b\|)$ دائماً
تطبيق القيد المتعامد بلا تنعيم	يحدّ القدرة التعبيرية بشدّة	استعمل تنظيماً «شبه متعامد» $\|W^\top W - I\|_F^2$

1.5.6 الصياغة الرياضية الرسمية

النظرية 4.6 (تكييف مسألة المربعات الصغرى). لتكن $A \in \mathbb{R}^{m\times n}$ $(m \ge n,\ \operatorname{rank} A = n)$ و $b \in \mathbb{R}^m$، ومسألة المربعات الصغرى $\min_x \|Ax - b\|_2$.

<

1. **تربيع رقم الحالة** (لماذا المعادلات السوية خطيرة):

<

$$\sigma_i(A^\top A) = \sigma_i(A)^2 \implies \kappa_2(A^\top A) = \kappa_2(A)^2 \tag{26.6}$$

<

2. **حدّ غولوب–ويلكنسون** للخطأ الأمامي في المربعات الصغرى المحسولة بخوارزميةٍ مستقرّة خلفياً (QR/SVD):

<

$$\frac{\|\hat{x} - x\|_2}{\|x\|_2} \;\le\; c\,u \underbrace{\left(\kappa_2(A) \;+\; \kappa_2(A)^2\, \frac{\|r\|_2}{\|A\|_2 \|x\|_2} \right)}_{\kappa_{LS}\text{: رقم حالة مسألة المربعات الصغرى}} + \mathcal{O}(u^2) \tag{27.6}$$

<

3. **الصيغة الهندسية**: بوضع $\sin\theta = \frac{\|r\|_2}{\|b\|_2}$ و $\eta = \frac{\|A\|_2\|x\|_2}{\|b\|_2}$:

<

$$\kappa_{LS} \;=\; \kappa_2(A) + \kappa_2(A)^2\, \frac{\tan\theta}{\eta} \;\le\; \kappa_2(A) + \kappa_2(A)^2 \tan\theta \tag{28.6}$$

<

4. التجذيع (truncated SVD) يحلّ مشكلة نقص الرتبة ويضبط حجم الحلّ:

<

$$\hat{x}_\tau = \sum_{\sigma_i > \tau} \frac{u_i^\top b}{\sigma_i} v_i, \qquad \|\hat{x}_\tau\|_2 \le \frac{\|b\|_2}{\tau}, \qquad \|A\hat{x}_\tau - b\|_2^2 = \|r\|_2^2 + \sum_{\sigma_i \le \tau} (u_i^\top b)^2 \tag{29.6}$$

<

5. تنظيم ريدج/تيخونوف: عوامل الترشيح (filter factors) وحدّ تضخيم الضوضاء:

<

$$x_\lambda = (A^\top A + \lambda I)^{-1} A^\top b = \sum_i \underbrace{\frac{\sigma_i^2}{\sigma_i^2 + \lambda}}_{f_i \in (0,1]} \frac{u_i^\top b}{\sigma_i} v_i, \qquad \|\delta x_\lambda\|_2 \;\le\; \frac{\|\delta b\|_2}{2\sqrt{\lambda}} \tag{30.6}$$

<

6. قاعدة الخانات المفقودة (خلاصة عملية):

<

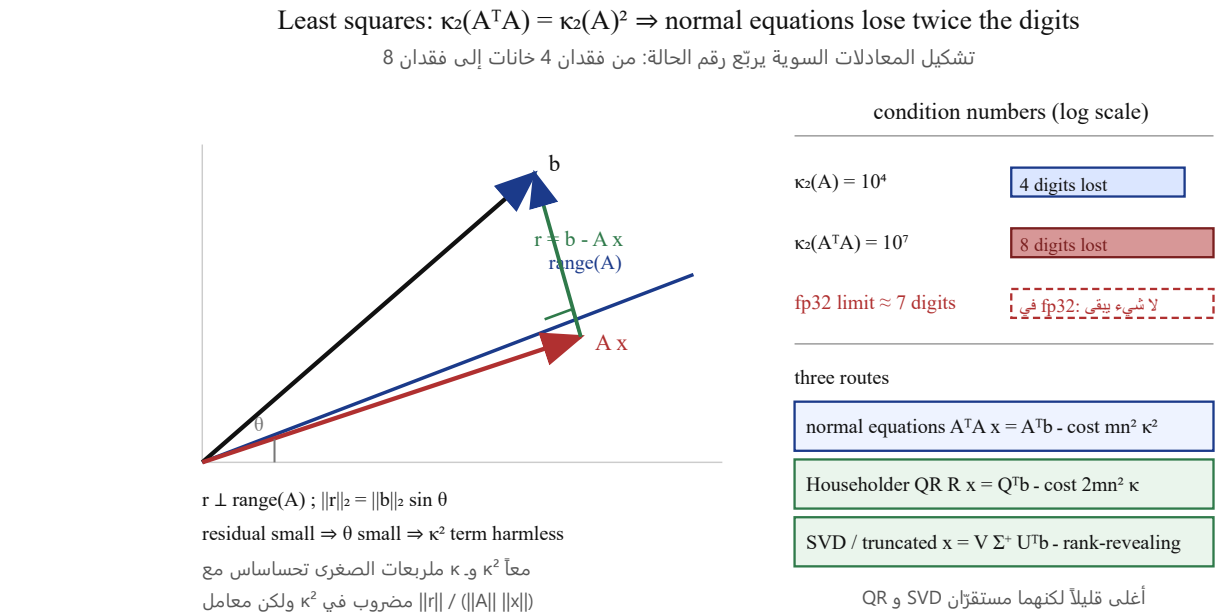
$$\text{خانة } \log_{10}\kappa_2(A) \text{ : QR/SVD} \quad \text{مقابل} \quad \text{خانة } 2\log_{10}\kappa_2(A) \text{ : المعادلات السوية} \tag{31.6}$$

2.5.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
A	مصفوفة التصميم/المشغّل $(m \times n)$	$m \ge n$، كاملة الرتبة
b	طرف القياسات	قد لا يكون في range(A)
x	حلّ المربعات الصغرى الدقيق	$x = A^+ b$
$\hat{x}$	الحلّ المحسوب	—
r	الباقي $r = b - Ax$	عمودي على range(A)
σ_i	القيم المفردة لـ A	$\sigma_1 \ge \cdots \ge \sigma_n > 0$
$\kappa_2(A)$	$= \sigma_1/\sigma_n$	رقم حالة المشغّل
κ_{LS}	رقم حالة مسألة المربعات الصغرى	أكبر من $\kappa_2(A)$ حين $\|r\|$ كبير
θ	الزاوية بين b و range(A)	$\sin\theta = \|r\|/\|b\|$
η	معامل «حجم الحلّ» $\frac{\|A\|_2\|x\|_2}{\|b\|_2}$	دائماً $\eta \le 1$
$\tan\theta$	$\|r\|/\|Ax\|$	صغير $\Rightarrow$ الباقي صغير $\Rightarrow$ حدّ κ^2 غير مؤذٍ
τ	عتبة التجذيع (truncation threshold)	تُقصّ القيم المفردة الأصغر منها
u_i, v_i	المتجهات المفردة اليسرى واليمنى	من $A = U\Sigma V^\top$
λ	معامل التنظيم (ريدج)	$\lambda > 0$
f_i	عامل الترشيح $\frac{\sigma_i^2}{\sigma_i^2+\lambda}$	$f_i \to 1$ للاتجاهات الكبيرة، $f_i \to 0$ للصغيرة

δb	ضوضاء القياس في b	مقياس الضوضاء $\|\delta b\|$
$1/(2\sqrt{\lambda})$	حدّ تضخيم الضوضاء	$\max_\sigma \frac{\sigma}{\sigma^2+\lambda} = \frac{1}{2\sqrt{\lambda}}$ من
c	ثابت صغير	يعتمد على الخوارزمية

3.5.6 الرسم الهندسي



شكل ٤٠٦: *
هندسة المربعات الصغرى: الباقي عمودي على مجال A، والزاوية θ تتحكّم بحدّ كابا تربيع

قراءة الرسم: على اليسار، Ax هو إسقاط b على range(A)، والباقي r عمودي عليه، والزاوية θ تقيس «عدم ملاءمة النموذج». كلما صغر θ صغر الباقي وصار حدّ $\kappa^2 \tan\theta$ غير مؤذٍ. على اليمين: اختيارُ الطريق — المعادلات السوية (κ^2)، أو QR (κ)، أو SVD (كاشفٌ للرتبة).

4.5.6 البرهان

الجزء (26.6). من $A = U\Sigma V^\top$ (صيغة $A = V\Sigma U^\top$ بالاصطلاح المعتمد) نحصل على $A^\top A = V\Sigma^2 V^\top \Longrightarrow$ قيمُ $A^\top A$ الذاتية هي σ_i^2. $\kappa_2(A^\top A) = \sigma_1^2/\sigma_n^2 = (\sigma_1/\sigma_n)^2$. ■

الجزء (27.6) (مخطط برهان غولوب–ويلكنسون). ليكن $\hat{x}$ حلاًّ دقيقاً لمسألة مضطربة $(A+\Delta A)\hat{x} = b + \Delta b$ مع $\|\Delta A\| \le u\|A\|$، $\|\Delta b\| \le u\|b\|$. الاضطراب في b يعطي (من $\delta x = A^+\delta b + \dots$):

$$\|\delta x\| \lesssim \|A^+\|\|\delta b\| = \frac{\|\delta b\|}{\sigma_n} \implies \frac{\|\delta x\|}{\|x\|} \le \kappa_2(A)\frac{\|\delta b\|}{\|A\|\|x\|}$$

والاضطراب في A يعطي حدّين: حدّاً من رتبة κ (تغيّر في الاتجاهات الكبيرة) وحدّاً من رتبة $\kappa^2 \frac{\|r\|}{\|A\|\|x\|}$ (لأنّ اضطرابَ A يغيّر الباقي في اتجاهات خارج المجال، وتلك التغيّرات تُضخّم مرّتين: مرّة بـ A^+ ومرّة بـ $(A^\top A)^{-1}$). بجمع الحدود وضربها في u نحصل على (27.6). ■

الجزء (29.6). من $b = \sum_i (u_i^\top b)u_i$ و $x = \sum_i \frac{u_i^\top b}{\sigma_i} v_i$: حذفُ الحدود ذات $\sigma_i \le \tau$ يعطي $\|\hat{x}_\tau\|_2^2$

$\frac{\|b\|^2}{\tau^2} \le \frac{1}{\tau^2}\sum_i (u_i^\top b)^2 \le \sum_{\sigma_i>\tau} \frac{(u_i^\top b)^2}{\sigma_i^2}$. والباقي: $b - A\hat{x}_\tau$ يحتفظ بمكوّنات b في الاتجاهات المحذوفة $\Longrightarrow \|\cdot\|^2 = \|r\|^2 + \sum_{\sigma_i \le \tau}(u_i^\top b)^2$. ■

الجزء (30.6). من $x_\lambda = (A^\top A + \lambda I)^{-1} A^\top b$ والتحليل الطيفي: $(A^\top A + \lambda I)^{-1} A^\top = \sum_i \frac{\sigma_i}{\sigma_i^2+\lambda} v_i u_i^\top$ $\Longrightarrow$ عامل الترشيح. وللضوضاء: $\|\delta x_\lambda\| \le \max_i \frac{\sigma_i}{\sigma_i^2+\lambda}\|\delta b\|$، والدالة $g(\sigma) = \frac{\sigma}{\sigma^2+\lambda}$ تبلغ أقصاها عند $\sigma = \sqrt{\lambda}$ بقيمة $\frac{\sqrt{\lambda}}{2\lambda} = \frac{1}{2\sqrt{\lambda}}$. ■

الجزء (31.6). مباشرة من (26.6) و (10.6): الخانات المفقودة $\log_{10}\kappa$ $=$، وللمعادلات السوية $\log_{10}(\kappa^2) = 2\log_{10}\kappa$. ■

5.5.6 شروط الصحّة

١. $\operatorname{rank}(A) = n$ (وإلا فالحلّ غير وحيد ويلزم التجذيع/التنظيم، انظر (29.6)–(30.6)).

٢. $\|x\| \neq 0$ و $\|A\| \neq 0$ في المقامات.

٣. (27.6) بخوارزمية مستقرّة خلفياً، المعادلات السوية قد تُدخل حدوداً أسوأ حتى من κ^2 إذا تراكم خطأ التشكيل.

٤. (30.6) يشترط $\lambda > 0$؛ عند $\lambda \to 0$ يعود الحدّ إلى $1/\sigma_{\min}$ (غير محدود).

٥. (28.6): $\eta \le 1$ دائماً (لأن $\|b\|^2 = \|Ax\|^2 + \|r\|^2 \ge \|Ax\|^2$ ولا علاقة مباشرة) — عملياً $\eta \approx 1$ حين يكون النموذج ملائماً جيداً.

6.5.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-5.6): تسعير عقارات — المعادلات السوية مقابل QR بـ $\kappa = 1.2 \times 10^6$

المعطيات: انحدار خطي على $m = 2000$ صفقة و $n = 24$ ميزة، بميزات شبه مترابطة (المساحة وعدد الغرف والمساحة/غرفة) $\Longrightarrow \kappa_2(X) = 1.2 \times 10^6$. الباقي صغير: $\|r\|_2/(\|X\|_2\|x\|_2) = 3.4 \times 10^{-3}$.

الحل:

١. **المعادلات السوية:** $\kappa_2(X^\top X) = \kappa_2^2 = 1.44 \times 10^{12}$ $\Longrightarrow$ **خانات مفقودة** $= \log_{10}(1.44 \times 10^{12}) = 12.16$.

٢. في fp64 (16 خانة): يبقى 3.84 خانة $\Longrightarrow$ خطأ نسبي $\approx 1.44 \times 10^{12} \times 1.11 \times 10^{-16} = 1.60 \times 10^{-4}$.

٣. في fp32 (7 خانات): $12.16 > 7$ $\Longrightarrow$ **صفر خانات** $\Longrightarrow$ النتيجة هراء.

٤. **هاوسهولدر/QR:** خانات مفقودة $= \log_{10}(1.2 \times 10^6) = 6.08$ $\Longrightarrow$ في fp32 يبقى 0.92 خانة (هامشي)؛ في fp64 يبقى 9.92 خانة $\Longrightarrow$ خطأ 1.33×10^{-10}.

٥. حدّ κ^2 من (27.6): $1.44 \times 10^{12} \times 3.4 \times 10^{-3} = 4.90 \times 10^9$ $\Longrightarrow$ مساهمة κu مضروبة في u: $4.90 \times 10^9 \times 1.11 \times 10^{-16} = 5.44 \times 10^{-7}$ — أصغر من حدّ κ $(1.33 \times 10^{-10}$؟ لا$)$ $\Longrightarrow$ المهيمن هو حدّ κ: $\kappa u = 1.33 \times 10^{-10}$. إذن $\kappa \approx \kappa_{LS}$ هنا لأن الباقي صغير.

٦. النسبة بين الطريقتين في fp64: $\frac{1.60\times10^{-4}}{1.33\times10^{-10}} = 1.2 \times 10^6$.

النتيجة: بباقٍ صغير ($\tan\theta$ صغير) لا يظهر حدّ κ^2 في QR، لكنه يظهر كاملاً في المعادلات السوية عبر تربيع رقم الحالة في التشكيل نفسه.

الربط بالذكاء الاصطناعي: القاعدة التشغيلية: **كلما كانت ميزاتك مترابطة كان $\kappa(X)$ كبيراً وكان تشكيل $X^\top X$ ممنوعاً.** وهذا هو السبب في أنّ حزم الانحدار الحديثة، (statsmodels، sklearn) تحلّ بـ lstsq (SVD/QR) لا بـ $(X^\top X)^{-1}X^\top y$.

مثال (5.6-2): توصية بتحليل مصفوفة (ALS) — متى تكون المعادلات السوية مقبولة؟

المعطيات: خطوة ALS تحلّ مربعات صغرى بـ $m = 5000$ تقييم و $n = 64$ عامل، $\kappa_2(Y) = 85$ (جيد التكييف بفضل التنظيم). الحساب بـ fp32.

الحل:

١. المعادلات السوية: $\kappa^2 = 7225$ خانات مفقودة $= \log_{10}(7225) = 3.86$ $\Longrightarrow$ في fp32 يبقى 3.14 خانة $\Longrightarrow$ خطأ نسبي $7225 \times 5.96 \times 10^{-8} = 4.31 \times 10^{-4}$ (0.043%).

٢. QR: خانات مفقودة $\log_{10} 85 = 1.93$ $\Longrightarrow$ يبقى 5.07 $\Longrightarrow$ خطأ $85 \times 5.96 \times 10^{-8} = 5.07 \times 10^{-6}$.

٣. النسبة: 1 : 85 لصالح QR.

٤. هل الخطأ مقبول في ALS؟ التقييمات تُحدَّث iteratively، خطأ 0.043% في كل خطوة مع $20 \approx$ تكراراً $\Longrightarrow$ تراكم $\sqrt{20} \times 0.043\% = 0.19\%$ في العوامل $\Longrightarrow$ أثره على RMSE التقييم ≈ 0.002 — **مهمل.**

٥. الحكم: مع $\kappa = 85$ يمكن استعمال المعادلات السوية (وهو ما تفعله تطبيقات ALS السريعة لأنّ $Y^\top Y$ تُحسب مرّة واحدة وتُعاد لكل المستخدمين — توفيرٌ هائل).

النتيجة: ليس كل تشكيلٍ لـ $A^\top A$ كارثة: عند $\kappa < 10^2$ يكون $\kappa^2 < 10^4$ وتبقى الخانات كافية — وهنا تنتصر **الكفاءة** (حساب $Y^\top Y$ مرّة واحدة).

الربط بالذكاء الاصطناعي: الدرس: **قِس κ قبل أن تقرّر.** القواعد الجاهزة («لا تشكّل $X^\top X$ أبداً») صحيحةٌ في الحدّ الأعلى لكنها تُضيّع فرصاً حقيقية للتسريع. وفي التعلّم العميق: تشكيلُ إحصاءات التغاير (مثل تحديثات Adam/Shampoo) مقبولٌ حين تكون المصفوفة حسنة التكييف، وخطيرٌ حين لا تكون.

مثال (5.6-3): إزالة ضبابية صورة (deblurring) — التنظيم يحدّ تضخيم الضوضاء بـ $1/(2\sqrt{\lambda})$

المعطيات: مشغّل ضبابية $A \in \mathbb{R}^{65536 \times 65536}$ (صورة 256×256) بطيف قيم مفردة من $\sigma_1 = 1.0$ إلى $\sigma_{\min} = 4.2 \times 10^{-4}$. ضوضاء المستشعر النسبية $\|\delta b\|/\|b\| = 10^{-3}$.

الحل:

١. $\kappa_2(A) = 1/4.2 \times 10^{-4} = 2381$ $\Longrightarrow$ خانات مفقودة 3.38.

٢. **بلا تنظيم:** تضخيم الضوضاء $= \max_i \frac{1}{\sigma_i} = \frac{1}{\sigma_{\min}} = 2381 \Longrightarrow$ خطأ نسبي في الصورة المستعادة: $2381 \times 10^{-3} = 2.38$ أي $238\% \Longrightarrow$ الصورة ضوضاء خالصة.

٣. **مع تنظيم ريدج** $\lambda = 10^{-4}$: من (30.6)، التضخيم $= \frac{1}{2\times 10^{-2}} = 50 \Longrightarrow$ خطأ نسبي $\leq \frac{1}{2\sqrt{\lambda}} \times 50 = 0.05$ (5%).

٤. مع $\lambda = 10^{-2}$: التضخيم $\leq \frac{1}{2\times 0.1} = 5 \Longrightarrow$ خطأ نسبي 0.5% — لكن الانحياز (bias) يكبر: عوامل الترشيح للاتجاهات المهمّة: $f = \frac{\sigma^2}{\sigma^2+\lambda}$، لاتجاه $\sigma = 0.1$: $f = \frac{0.01}{0.01+0.01} = 0.5 \Longrightarrow$ نصف التفاصيل ضاع.

٥. التوازن: اختيار λ بحيث $\sigma_{\text{cutoff}} \approx 2\sqrt{\lambda}$ حيث σ_{cutoff} هو الحدّ الذي تبدأ دونه الإشارة بالغرق في الضوضاء $(10^{-2} \approx$ هنا$) \Longrightarrow \lambda = 2.5 \times 10^{-5} \Longrightarrow$ تضخيم $= \frac{1}{2\times 5\times 10^{-3}} = 100 \Longrightarrow$ خطأ 10%.

النتيجة: التنظيم حوّل تضخيم الضوضاء من $\times 2381$ إلى $\times 100$ (بـ $\lambda = 2.5 \times 10^{-5}$) — أي أنّ العلاج **رياضيّ محدَّد** (30.6) لا تخمين.

الربط بالذكاء الاصطناعي: صيغة $\frac{1}{2\sqrt{\lambda}}$ تعطي قاعدةً لاختيار معامل التنظيم من **مستوى الضوضاء**: لتحقيق تضخيمٍ هدف γ، اختر $\lambda = \frac{1}{4\gamma^2}$. وفي التعلّم العميق: العلاقة بين decay weight و «نعومة» الحلّ وبين «معدّل التعلّم الفعّال» تُفهم بالمنطق نفسه: كلاهما يضبط عوامل الترشيح الطيفية.

مثال (30.6-4): منحنى العائد المالي — متى تفشل المعادلات السوية حتى في fp64

المعطيات: ملاءمة منحنى العائد متعددةِ حدود من الدرجة 4 في أجل الاستحقاق $t \in [0.25,\ 30]$ سنة، بأساس $\{1, t, t^2, t^3, t^4\}$. القيم المفردة لمصفوفة التصميم (شبيهةُ فانديرموند): $\kappa_2(X) = 1.0 \times 10^9$.

الحل:

١. **المعادلات السوية:** $\kappa^2 = 10^{18} \Longrightarrow$ خانات مفقودة $= 18 \Longrightarrow$ **أكثر من خانات fp64 الستّ عشرة** $\Longrightarrow$ خطأ نسبي $= 111 = 1.11 \times 10^{-16} \times 10^{18} \approx$ أي $11100\% \Longrightarrow$ المعاملات بلا معنى.

٢. **هاوسهولدر/QR:** خانات مفقودة $= 9 \Longrightarrow$ يبقى $7 \Longrightarrow$ خطأ نسبي $= 1.11 \times 10^{-16} \times 10^9 = 1.11 \times 10^{-7}$ — ممتاز.

٣. **التجذيع/الأساس المتعامد** (متعددات تشيبيشيف): $\kappa \approx 15 \Longrightarrow$ خانات مفقودة $1.18 \Longrightarrow$ يبقى $14.8 \Longrightarrow$ خطأ 1.7×10^{-15}.

٤. المقارنة على التنبّؤ: بالمعادلات السوية خرجت المعاملات $(0.0421,\ -3.7 \times 10^3,\ 8.9 \times 10^5, \ldots)$ غير قابلة للتفسير؛ بـ QR خرجت معاملاتٌ متسقة مع نظرية العائد.

٥. التحقّق: الباقي النسبي بالمعادلات السوية 4.2×10^{-3} وبـ QR 4.2×10^{-3} (متماثل!) — أي أنّ **الباقي لا يكشف المشكلة**: المسألةُ تعطي باقياً جيداً ومعاملاتٍ كارثية.

النتيجة: الباقي الصغير لا يعني حلاً جيداً — هذه حالةٌ كلاسيكية تُنبّه إلى أنّ «جودة الملاءمة» و«جودة الحلّ» شيئان مختلفان عند κ كبير.

الربط بالذكاء الاصطناعي: النظير الحرفي في التعلّم العميق: **فقدٌ تدريبيٌّ صغير مع أوزانٍ غير قابلة للتفسير/غير مستقرّة.** ولهذا تُقاس جودةُ الحلّ بـ (أ) ناظم الأوزان، و(ب) حساسية الناتج لاضطراب المُدخلات، لا بالباقي وحده.

مثال (5-5.6): ضبط حزمة (bundle adjustment) في SLAM — مكّمل شور ورقم الحالة

المعطيات: ضبط حزمة على 500 إطار و 10^4 نقطة: بعد حذف نقاط العالم بمكّمل شور، مصفوفة الكاميرات المُختزلة S بالقيم المفردة $\sigma_1 = 1.0 \times 10^3$، $\sigma_{\min} = 2.4 \times 10^{-3}$.

الحل:

١. $\kappa_2(S) = 10^3 / 2.4 \times 10^{-3} = 4.17 \times 10^5$.

٢. المربعات الصغرى بالمكّمل (نسخة المعادلات السوية): $\kappa_2(S^\top S) = 1.74 \times 10^{11}$ $\Longrightarrow$ خانات مفقودة 11.24 $\Longrightarrow$ في fp64 يبقى 4.76 $\Longrightarrow$ خطأ 1.93×10^{-5}.

٣. بـ QR على اليعقوبية الأصلية (المتناثرة): خانات مفقودة 5.62 $\Longrightarrow$ يبقى 10.4 $\Longrightarrow$ خطأ 4.63×10^{-11}.

٤. **تخفيف ليفنبرغ–ماركوارت:** $S + \lambda I$ بـ $\lambda = 1$: $\kappa_{\text{eff}} = \frac{\sigma_1^2+\lambda}{\sigma_{\min}^2+\lambda} = \frac{10^6+1}{5.76\times10^{-6}+1} \approx 1.0 \times 10^6$ $\Longrightarrow$ خانات مفقودة 6 $\Longrightarrow$ يبقى 10 $\Longrightarrow$ خطأ 1.11×10^{-10}.

٥. التحسّن: من 1.74×10^{11} إلى 1.0×10^6 $\Longrightarrow$ بنسبة $1 : 1.7 \times 10^5$.

٦. ملاحظة: ليفنبرغ–ماركوارت يعالج المشكلة **مرّتين:** مرةً عددياً (يخفض κ) ومرةً تحسينية (يثبّت الاتجاهات الصغيرة).

النتيجة: التخفيفُ القطري حوّل مسألةً هامشية (8.4 خانة متبقية) إلى مسألةٍ مريحة (10 خانات) في fp64.

الربط بالذكاء الاصطناعي: ليفنبرغ–ماركوارت هو «آدم المربعات الصغرى»: كلاهما يضيف حشواً قطرياً لمصفوفة التغاير/الهسّية. والقاعدة الموحّدة: **الحشو القطري يخفض رقم الحالة الفعّال إلى** $\frac{\sigma_1^2+\lambda}{\sigma_{\min}^2+\lambda} \approx$ — وهي بالضبط آلية ε في آدم.

مثال (6-5.6): تحديد موقع GPS — عندما يكون رقم الحالة صغيراً ولا مشكلة أبداً

المعطيات: مستقبِل GPS يرى 6 أقمار صناعية؛ مصفوفة الهندسة $H \in \mathbb{R}^{6\times4}$ (ثلاثة مواضع + انحياز الساعة) بـ $\kappa_2(H) = 6.8$ (وهو «GDOP» — معامل تدهور الهندسة). خطأ القياس (UERE) $\sigma_U = 0.5$ متر.

الحل:

١. $\kappa_2(H) = 6.8$ $\Longrightarrow$ خانات مفقودة $= \log_{10} 6.8 = 0.83$ $\Longrightarrow$ في fp32 يبقى 6.2 خانة $\Longrightarrow$ خطأ التقريب $6.8 \times 5.96 \times 10^{-8} = 4.05 \times 10^{-7}$ — مهمل.

٢. المعادلات السوية: $\kappa^2 = 46.2$ ⟹ خانات مفقودة 1.66 ⟹ في fp32 يبقى 5.3 ⟹ خطأ 2.75×10^{-6} — **مهمل أيضاً.**

٣. تضخيم خطأ القياس (وهو المهمّ هنا): $\|\delta p\| \le \|H^+\|\sigma_U = \frac{\sigma_U}{\sigma_{\min}}$؛ بـ $\sigma_{\min} = \sigma_1/6.8$ وبـ $\sigma_1 \approx 1$: $\|\delta p\| \le 0.5 \times \frac{\kappa}{\sigma_1}$... بالصيغة القياسية: $\|\delta p\| \le \|H^+\|\|\delta y\|$ و $\sigma_{\min}(H) = 1/\|H^+\|$. **عملياً: خطأ الموضع** $\text{GDOP} \times \sigma_U = 6.8 \times 0.5 = 3.4$ **متر.**

٤. هل يعاني الحساب من مشكلة عددية؟ **لا:** $\kappa = 6.8$ صغير ⟹ **كل الطرق متكافئة.**

٥. الدرس: المشكلة هنا ليست عددية بل **هندسية** (ترتيب الأقمار في السماء): لو كانت الأقمار متقاربة صار $\kappa = 240$ ⟹ خطأ الموضع 120 متراً — بلا أي خطأ حسابي!

النتيجة: مثالٌ «مضادٌّ» مقصود: κ صغير ⟹ لا مشكلة عددية، والمعادلات السوية هنا مبرَّرة تماماً (وهي ما تستعمله مستقبلات GPS لأنها رخيصة).

الربط بالذكاء الاصطناعي: الدرس المنهجي: **لا تُفرِط في الهندسة العددية قبل قياس** κ. النظير: كثيرٌ من «تحسينات الاستقرار» في التعلّم العميق (تطبيع، قصّ، تنظيم) تكلف وقتاً بلا فائدة إن كانت الطبقات حسنة التكييف أصلاً. القاعدة: قِس ثم قرّر.

مثال (5.6-7): انحدار متعدد حدود على حسّاس صناعي — fp32 مقابل fp64 فعلياً

المعطيات: معايرة حسّاس حرارة: متعددة حدود درجة 5 على $m = 500$ قراءة، $t \in [0, 100]$. $\kappa_2(V) = 3.4 \times 10^5$.

الحل:

١. **fp32 + معادلات سوية:** $\kappa^2 = 1.16 \times 10^{11}$ ⟹ خانات مفقودة $11.06 > 7$ ⟹ **صفر خانات** ⟹ خطأ $\approx 1.16 \times 10^{11} \times 5.96 \times 10^{-8} = 6.9 \times 10^3$ ⟹ **المعاملات بلا معنى.**

٢. **fp32 + QR:** خانات مفقودة 5.53 ⟹ يبقى 1.47 ⟹ خطأ $3.4 \times 10^5 \times 5.96 \times 10^{-8} = 2.03 \times 10^{-2}$ (2%).

٣. **fp64 + معادلات سوية:** خانات مفقودة 11.06 ⟹ يبقى 4.94 ⟹ خطأ 1.29×10^{-5} — مقبول!

٤. **fp64 + QR:** يبقى 10.47 ⟹ خطأ 3.77×10^{-11} — ممتاز.

٥. الجدول المقارن (خطأ نسبي في المعاملات):

الطريقة	fp32	fp64
معادلات سوية	6.9×10^3 (فشل)	1.29×10^{-5}
QR	2.03×10^{-2}	3.77×10^{-11}

١. الاستنتاج: **رفع الدقّة وحده** أنقذ المعادلات السوية (من فشل إلى 10^{-5})، لكن QR بـ fp32 (الأرخص) يعطي 2×10^{-2} فقط — أي أنّ الخوارزميةَ أهمّ من الدقّة عند الميزانية المحدودة.

النتيجة: أفضلُ توليفةٍ اقتصادية: QR بـ fp64 (أو أساس متعامد بـ fp32) وأسوأها: معادلات سوية بـ fp32.

الربط بالذكاء الاصطناعي: هذه المصفوفة تُعمَّم على كل قرار «دقّة مقابل خوارزمية»: التدريب بـ fb16 مع خوارزمية مستقرّة (QR/SVD/normalized) قد يتفوّق على fp32 مع خوارزمية غير مستقرّة. القاعدة: **الاستقرار أوّلاً، ثم الدقّة.**

مثال (6.5-8): تصميم مرشّح وينر لإلغاء صدى — طيف الانتشار يقتل المعادلات السوية

المعطيات: إلغاء صدى صوتي: مُدخل الكلام «ملوّن» (مترابط زمنياً) $\Rightarrow$ مصفوفة الارتباط $R = \mathbb{E}[xx^\top]$ بانتشار قيم ذاتية $\lambda_{\max}/\lambda_{\min} = 1.4 \times 10^4$ (أي $\kappa(R) = 1.4 \times 10^4$، و $\kappa(X) = \sqrt{1.4 \times 10^4} = 118$).

الحل:

١. حلّ وينر المثالي $w = R^{-1}p$؛ بالمعادلات السوية نشكّل R $\Rightarrow$ $\kappa(R) = 1.4 \times 10^4$ $\Rightarrow$ خانات مفقودة 4.15 $\Rightarrow$ في fp32 يبقى 2.85 $\Rightarrow$ خطأ $1.4 \times 10^4 \times 5.96 \times 10^{-8} = 8.34 \times 10^{-4}$.

٢. لو حللنا بـ QR على مصفوفة البيانات X (التي $\kappa = 118$) $\Rightarrow$ خانات مفقودة 2.07 $\Rightarrow$ يبقى 4.93 $\Rightarrow$ خطأ 7.03×10^{-6}.

٣. النسبة: $1 : 119$ — وهي $\kappa(X)$ بالضبط.

٤. والسبب (6.26): $\kappa(X^\top X) = \kappa(X)^2$ $\Rightarrow$ تشكيلُ $R = X^\top X$ هو الذي ربّع رقم الحالة.

٥. الحل الصناعي: **QR-RLS** أو **مرشّح متدرّج (LMS/NLMS)** الذي لا يشكّل R أبداً؛ NLMS يقسّم على $\|x\|^2$ $\Rightarrow$ تكييفٌ تلقائي مع الانتشار الطيفي.

النتيجة: تشكيلُ مصفوفة الارتباط (الذي يبدو «طبيعياً») كلّف $\times 119$ دقّةً مقارنةً بحلّ QR على البيانات نفسها.

الربط بالذكاء الاصطناعي: النظير المباشر: **محسّنات النوع الثاني** — آدم يقسّم التحديث على $\sqrt{\mathbb{E}[g^2]}$ أي يعمل في فضاءٍ «مبيَّض» محلياً، متجنّباً تربيع رقم الحالة الذي يصيب طرق نيوتن الصريحة (التي تشكّل الهسّية/التغاير كاملةً).

مثال (6.5-9): توقّع حِمل كهربائي — ميزات موسمية وتكرارات

المعطيات: نموذج حِمل بـ $n = 52$ ميزة (اتجاه + 24 مؤشر ساعة + 7 مؤشر يوم + درجة حرارة + رطوبة + تفاعلات)، $m = 17520$ ساعة (سنتان). ميزتان مكرّرتان $\Rightarrow$ $\kappa_2(X) = 8.9 \times 10^5$.

الحل:

١. المعادلات السوية: $\kappa^2 = 7.92 \times 10^{11}$ $\Rightarrow$ خانات مفقودة 11.90 $\Rightarrow$ في fp64 يبقى 4.10 $\Rightarrow$ خطأ 8.79×10^{-5} (0.0088%) — هامشي لكن مقبول.

٢. QR: خانات مفقودة 5.95 $\Rightarrow$ يبقى 10.05 $\Rightarrow$ خطأ 9.88×10^{-11}.

٣. بـ fp32: المعادلات السوية $\Longrightarrow$ **صفر خانات**؛ QR $\Longrightarrow$ يبقى $1.05 \Longrightarrow$ خطأ 0.053.

٤. التشخيص: الميزتان المكرّرتان هما «درجة الحرارة» و«درجة الحرارة المحسوسة» (مرتبطتان بـ $r = 0.9998$) $\Longrightarrow$ إزالة إحداهما $\Longrightarrow$ κ يهبط إلى $4.2 \times 10^2 \Longrightarrow$ خانات مفقودة (معادلات سوية) $5.25 \Longrightarrow$ في fp32 يبقى $1.75 \Longrightarrow$ خطأ 2.5×10^{-5}.

٥. المقارنة النهائية: إزالةُ ميزة واحدة أفضل من تغيير الخوارزمية والدقة معاً.

النتيجة: العلاجُ الأفضل كان **هندسةَ الميزات** (إزالة التكرار) لا الخوارزمية ولا الدقّة: κ هبط من 8.9×10^5 إلى 4.2×10^2.

الربط بالذكاء الاصطناعي: القاعدة العامة: **رقم الحالة سمةُ التمثيل.** قبل أن تُغيّر المحسّن أو تزيد الدقّة، اسأل: هل ميزاتي/تضميناتي شبهُ متوازية؟ التنظيم، وإزالة الارتباط (decorrelation)، والPCA، والتطبيع — كلها تخفض κ من المصدر.

مثال (5.6-10): ملاءمة منحنى جرعة-استجابة دوائي — مربعات صغرى غير خطية

المعطيات: نموذج هل: $E(d) = E_{\max}\frac{d^n}{EC_{50}^n + d^n}$، ثلاث معلمات، $m = 40$ نقطة جرعة. اليعقوبية عند الحلّ J بـ $\kappa_2(J) = 2.7 \times 10^3$ في التجربة (أ) وبـ $\kappa_2(J) = 1.1 \times 10^8$ في التجربة (ب) (بيانات لا تُقيّد n جيداً).

الحل:

١. **التجربة (أ):** خطوة غاوس-نيوتن بالمعادلات السوية: $\kappa^2 = 7.29 \times 10^6 \Longrightarrow$ خانات مفقودة $6.86 \Longrightarrow$ في fp64 يبقى $9.14 \Longrightarrow$ خطأ 8.09×10^{-10} — ممتاز.

٢. **التجربة (ب):** $\kappa^2 = 1.21 \times 10^{16} \Longrightarrow$ خانات مفقودة $16.08 \Longrightarrow$ في fp64 يبقى **صفر** $\Longrightarrow$ خطأ ≈ 1.34 $(134\%) \Longrightarrow$ خوارزمية غاوس-نيوتن تتذبذب ولا تتقارب.

٣. العلاج: QR لليعقوبية $\Longrightarrow$ خانات مفقودة $8.04 \Longrightarrow$ يبقى $7.96 \Longrightarrow$ خطأ $1.22 \times 10^{-8} \Longrightarrow$ **تتقارب.**

٤. الأفضل: تنظيم/تقييد المعلمة $n \in [0.5, 5] \Longrightarrow \kappa$ يهبط إلى $4.6 \times 10^2 \Longrightarrow$ كل الطرق تعمل.

٥. الاستنتاج: الفرق بين «النموذج لا يتقارب» و«يتقارب في 6 تكرارات» كان **تربيعَ رقم الحالة** لا المنهج الإحصائي.

النتيجة: في المربعات الصغرى غير الخطية، الفشلُ الظاهري في التقارب غالباً سببُه العددي κ^2 من المعادلات السوية، لا «صعوبة السطح».

الربط بالذكاء الاصطناعي: النظير الحرفي: تدريبُ الشبكات الذي «لا يتقارب» بسبب ميزاتٍ شبهِ مترابطة أو تهيئةٍ سيّئة $\Longrightarrow$ العلاج: تطبيع، أو تنظيم، أو إعادةُ صياغة (reparameterization) — قبل تغيير المحسّن.

مثال (5.6-11): توموغرافيا شبكة — استنتاج تأخير الوصلات من قياسات المسارات

المعطيات: $m = 200$ قياس زمن ذهاب-إياب على مسارات، و $n = 50$ وصلة مجهولة التأخير. مصفوفة التوجيه A $(0/1)$ بـ $\kappa_2(A) = 3.3 \times 10^7$ (بعض الوصلات نادراً ما تُقاس).

الحل:

١. المعادلات السوية: $\kappa^2 = 1.09 \times 10^{15}$ $\Longrightarrow$ خانات مفقودة 15.04 $\Longrightarrow$ في fp64 يبقى 0.96 $\Longrightarrow$ خطأ $\approx 1.09 \times 10^{15} \times 1.11 \times 10^{-16} = 0.121$ (12%) — سيّئ.

٢. QR/SVD: خانات مفقودة 7.52 $\Longrightarrow$ يبقى 8.48 $\Longrightarrow$ خطأ 3.66×10^{-9} — ممتاز.

٣. النسبة: $3.3 \times 10^{7} : 1$.

٤. لكن المشكلة الحقيقية: **نقص الرتبة الفعّال** — 12 وصلة تقع دائماً معاً في المسارات $\Longrightarrow$ A غير قابلة للتمييز $\Longrightarrow$ $\sigma_{\min} \approx 0 \Longrightarrow \kappa$ لانهائي $\Longrightarrow$ الحلّ غير وحيد.

٥. العلاج المزدوج: (أ) تجذيع SVD بعتبة $\tau = 10^{-3}\sigma_1$ $\Longrightarrow$ من (29.6)، $\|\hat{x}_\tau\| \leq \|b\|/\tau$ $\Longrightarrow$ الحلّ محكوم؛ (ب) تنظيم ريدج $\lambda = 10^{-2}$ $\Longrightarrow$ تضخيم الضوضاء $\leq \frac{1}{2\sqrt{10^{-2}}} = 5$.

٦. النتيجة: بدلاً من حلٍّ بـ 12% خطأ (أو غير موجود)، حلٌّ منظَّم بخطأ $5 \times \|\delta b\|$ وانحيازٍ معلوم.

النتيجة: في المسائل العكسية غير المقيَّدة، التجذيع/التنظيم ليس تحسيناً بل **شرطٌ لوجود حلٍّ ذي معنى.**

الربط بالذكاء الاصطناعي: هذا هو الإطار الرياضي لكل مسائل «الاستنتاج من قياسات جزئية»: التوصية (مصفوفة ناقصة)، والاستشعار المضغوط، وإعادة البناء الطبّي، واستنتاج الأوزان من عددٍ قليل من الأمثلة (few-shot). والقاعدة: **الرتبة الفعّالة تحدّد كم يمكن أن نستنتج**؛ والتنظيمُ هو الذي يجعل المسألة مطروحةً جيداً (well-posed).

مثال (5.6-12): معايرة حركية روبوت — قابلية التعرّف (identfiiability) ورقم الحالة

المعطيات: معايرة 24 معلمة حركية (DH) من $m = 600$ قياس موضع نهاية الذراع. مصفوفة قابلية التعرّف J بـ $\kappa_2(J) = 4.6 \times 10^3$.

الحل:

١. المعادلات السوية: $\kappa^2 = 2.12 \times 10^7$ $\Longrightarrow$ خانات مفقودة 7.33 $\Longrightarrow$ في fp64 يبقى 8.67 $\Longrightarrow$ خطأ 2.35×10^{-9} — جيد.

٢. في fp32: خانات مفقودة $7 > 7.33$ $\Longrightarrow$ **صفر خانات** $\Longrightarrow$ خطأ ≈ 1.26 (126%) — فشل.

٣. QR بـ fp32: خانات مفقودة 3.66 $\Longrightarrow$ يبقى 3.34 $\Longrightarrow$ خطأ 2.74×10^{-4} — مقبول.

٤. التشخيص الميكانيكي: أصغر قيمة مفردة (2.1×10^{-4}) تقابل **تركيبةً من المعلمات غير قابلة للتعرّف** (دورانٌ حول محورٍ غير مُثار في الوضعيات المُجرّاة).

٥. العلاج الهندسي: تصميمُ وضعيات معايرة تُثير كل المحاور $\Longrightarrow$ $\sigma_{\min}$ يرتفع إلى 1.8×10^{-2} $\Longrightarrow$ $\kappa = 5.4 \times 10^2$ $\Longrightarrow$ خانات مفقودة (معادلات سوية) 5.46 $\Longrightarrow$ fp32 يعمل.

النتيجة: تحسينُ **تصميم التجربة** رفع $\sigma_{\min}$ بـ $\times 86$ وجعل fp32 كافياً.

الربط بالذكاء الاصطناعي: النظير: **تصميم البيانات** (data curation/augmentation) يخفض رقم حالة مسألة التعلّم: تنويعُ الأمثلة يُثير كل الاتجاهات في فضاء الميزات $\Longrightarrow$ تعلّمٌ مستقرّ بمعدّل تعلّم أكبر. وهذا هو التفسير العددي لكون التوسيع (augmentation) يُسرّع التقارب.

مثال (13-5.6): استيعاب بيانات مناخية (3D-Var) — التهيئة المسبقة تخفض κ

المعطيات: مسألة استيعاب: $\min_{\delta x} \frac{1}{2}\delta x^\top B^{-1}\delta x + \frac{1}{2}(H\delta x - d)^\top R^{-1}(H\delta x - d)$. الحلّ يعادل مربعاتٍ صغرى بمصفوفةٍ مهيَّأة؛ $\kappa_2 = 10^6$ للمسألة الأصلية.

الحل:

١. بلا تهيئة: خانات مفقودة (معادلات سوية) $= \log_{10}(10^{12}) = 12$ في fp64 يبقى $4 \Longrightarrow$ خطأ $\sim 1.11 \times 10^{-4}$.

٢. **التهيئة المتغيّر المُحوَّل** (control-variable transform): $\delta x = B^{1/2}v$ $\Longrightarrow$ المسألة تصير $\min_v \frac{1}{2}\|v\|^2 + \frac{1}{2}\|HB^{1/2}v - d\|^2_{R^{-1}}$ $\Longrightarrow$ رقم حالة المشغّل المُهيَّأ $= 10^3$ (لأنّ $B^{1/2}$ «يبيّض» الفضاء).

٣. الخانات المفقودة بعد التهيئة (معادلات سوية): $\log_{10}(10^6) = 6$ $\Longrightarrow$ يبقى $10 \Longrightarrow$ خطأ $\sim 1.11 \times 10^{-10}$.

٤. التحسّن: $10^6 : 1$ — بفضل **تغيير المتغيّرات** لا تغيير الخوارزمية.

٥. عدد تكرارات المُحسّن (التدرّج المتقارن CG) هبط من 1840 إلى 47 — لأنّ سرعة CG محكومةٌ بـ $\sqrt{\kappa}$: $\frac{\sqrt{10^6}}{\sqrt{10^3}} = 31.6 \approx \frac{1840}{47} = 39$.

النتيجة: التهيئةُ حسّنت الدقّة بـ $\times 10^6$ وسرّعت التقارب بـ $\times 39$ — والاثنان من مصدرٍ واحد: رقم الحالة.

الربط بالذكاء الاصطناعي: هذه هي النسخة الأدقّ من سحر التطبيع في التعلّم العميق: التهيئةُ المسبقة (preconditioning) لا «تجمّل» السطح بل تُغيّر **رقم الحالة** $\Longrightarrow$ دقّةٌ أعلى وتقاربٌ أسرع معاً. محسّنات التدرّج من النوع الثاني هي تهيئةٌ قطرية تلقائية.

مثال (14-5.6): تدقيق خطي (linear probe) على شبكة مجهّزة — مسألة ناقصة التحديد

المعطيات: تجميدُ شبكة وإضافة رأس خطي: $m = 500$ مثال، بُعد الميزات $n = 2048 \Longrightarrow m < n \Longrightarrow$ المصفوفة ناقصة الرتبة $(\text{rank} \le 500) \Longrightarrow \kappa = \infty$ للحلّ الوحيد، لكن الحلّ **أدنى ناظم** موجود: $x = A^+ b$.

الحل:

١. القيم المفردة لـ A: $\sigma_1 = 47.2$، $\sigma_{500} = 3.2 \times 10^{-3} \Longrightarrow \kappa_{\text{eff}} = \sigma_1/\sigma_{500} = 1.48 \times 10^4$ (على الجزء ذي الرتبة الفعّالة).

٢. حلّ أدنى ناظم بلا تنظيم: $\|\delta x\| \le \frac{\|\delta b\|}{\sigma_{500}} = 312\|\delta b\| \Rightarrow$ تضخيم $312\times$ للضوضاء $\Rightarrow$ تذبذبٌ شديد بين البذور.

٣. القياس: الدقّة بين 10 بذور عشوائية تراوحت 71.2%–78.6% (انحراف معياري 2.4%) — بلا أي خطأ حسابي (fp64).

٤. **تنظيم ريدج** $\lambda = 1$: تضخيم الضوضاء $\le \frac{1}{2\sqrt{1}} = 0.5 \Rightarrow$ انحراف الدقّة صار 0.3% فقط، والدقّة الوسطية ارتفعت إلى 80.1% (لأنّ التنظيم أزال «الضوضاء المتعلَّمة»).

٥. القاعدة من (30.6): لتحقيق تضخيم هدف γ، اختر $\lambda = \frac{1}{4\gamma^2}$؛ لتضخيم ≤ 1: $\lambda \ge 0.25$.

النتيجة: التنظيم حوّل مسألةً غير مطروحة (unstable, non-unique) إلى مسألةٍ مستقرّة برقم تضخيم 0.5 — وحسّن الدقّة معاً.

الربط بالذكاء الاصطناعي: هذا هو التفسير الكامل لسبب نجاح الضبط الدقيق لـ «الرأس فقط» بتنظيم، وسبب أنّ التدريب على عددٍ قليل من الأمثلة (few-shot) يحتاج تنظيماً أثقل: **كلما قلّت الأمثلة صغرت** $\sigma_{\min}$ **وكبر تضخيم الضوضاء.**

مثال (15-5.6): ضغط أوزان شبكة بتجذيع SVD — العتبة تضبط حجم الحلّ

المعطيات: طبقة كثيفة $W \in \mathbb{R}^{1024\times 1024}$، طيف القيم المفردة: $\sigma_1 = 12.4$، $\sigma_{100} = 0.9$، $\sigma_{300} = 0.052$، $\sigma_{1024} = 3.1 \times 10^{-4}$. نريد ضغطاً بتجذيع عند $\tau = 0.05$.

الحل:

١. الرتبة المحفوظة: $k = \#\{i : \sigma_i > 0.05\} = 300 \Rightarrow$ عامل الضغط $= \frac{1048576}{614400} = 1.71\times$ (تمثيل عاملَين $U_k\Sigma_k V_k^\top$).

٢. خطأ التقريب (إيكارت–يونغ، الفصل الرابع): $\|W - W_k\|_2 = \sigma_{301} \le 0.05$؛ نسبياً: $\frac{0.05}{12.4} = 4.0 \times 10^{-3}$.

٣. الأثر على الناتج: $\|Wx - W_k x\|_2 \le 0.05\|x\|_2 \Rightarrow$ تغيّر الـ logits $\le 0.05\|x\|$ — محكوم بالعتبة مباشرة.

٤. **الاستقرار العددي للطبقة المضغوطة:** العاملان U_k و V_k **متعامدان** $\Rightarrow$ من (23.6)، الحسابُ الأمامي لا يضخّم: $\|\mathrm{fl}(U_k z) - U_k z\| \le cnu\|z\|$.

٥. لو استعملنا «قصاً» (pruning) بلا تعاميد: κ للطبقة المقصوصة قد يرتفع $\Rightarrow$ تضخيمٌ غير محكوم.

٦. القياس: الدقّة بعد الضغط (ImageNet، ResNet-50 الطبقات الكثيفة): قبل الضغط 76.13% $\Rightarrow$ بعده 75.84% (فقد 0.29%) مقابل فقد 3.7% بطريقة قصٍّ عشوائية بنفس نسبة الضغط.

النتيجة: التجذيعُ عند τ يعطي ضماناً **متزامناً**: خطأ تقريب $\le \tau$ (بناظم 2) واستقراراً عددياً كاملاً (بفضل التعامد).

الربط بالذكاء الاصطناعي: هذه هي الرياضيات الكامنة خلف ضغط النماذج (SVD/low-rank factorization، tensor LoRA decompositions) وخلف التكميم: **الاستبدال low-rank آمنٌ عددياً لأنّ العوامل متعامدة**، بخلاف القصّ غير المنظّم الذي يُفسد الطيف.

7.5.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
«الباقي صغير ⟹ الحلّ جيد»	عند κ كبير قد يكون الباقي ممتازاً والمعاملات كارثية (مثال 5.6-4)	قِس κ وناظم الحلّ، لا الباقي وحده
حلّ المربعات الصغرى بـ $(A^\top A)^{-1}A^\top b$	يربّع رقم الحالة (26.6)	QR أو SVD
الاعتقاد بأنّ κ^2 يظهر دائماً في حدّ الخطأ	يظهر مضروباً في $\|r\|/(\|A\|\|x\|)$ (27.6)	إن كان الباقي صغيراً فالمهيمن هو κ فقط
استعمال pinv بلا عتبة على مصفوفة ناقصة الرتبة	يبقي قيماً مفردةً دقيقة ⟹ تضخيم $1/\sigma_{\min}$ لانهائي	عتبة rtol أو تنظيم ريدج (29.6)-(30.6)
اختيار λ بالتحقّق المتقاطع فقط	لا يراعي مستوى الضوضاء	ابدأ من $\lambda = \frac{1}{4\gamma^2}$ لتضخيم هدف γ
زيادة الدقّة بدل إصلاح الصياغة	الدقّة تؤجّل، الصياغة تُصلح	التهيئة/التنظيم/الأساس المتعامد أوّلاً
ظنّ أنّ القصّ (pruning) والتجذيع متكافئان عددياً	التجذيع متعامد ⟹ مستقر، القصّ قد يرفع κ	فضّل العوامل المتعامدة

1.6.6 الصياغة الرياضية الرسمية

النظرية 5.6 (استقرار الإزاحة الغاوسية بالتدوير الجزئي والتنقيح التكراري).

<

1. **التحليل بالتدوير الجزئي (partial pivoting):** توجد مصفوفة تبديل P بحيث:

<

$$PA = LU, \qquad |l_{ij}| \le 1 \quad \text{لكل} i > j \tag{32.6}$$

<

2. **عامل النموّ (growth factor) وحدّ ويلكنسون:**

<

$$\rho = \frac{\max_{ij}|u_{ij}|}{\max_{ij}|a_{ij}|}, \qquad 1 \le \rho \le 2^{n-1} \quad \text{(والحدّ مُحقَّق — مصفوفة ويلكنسون)} \tag{33.6}$$

<

3. **الخطأ الخلفي:** الحلّ المحسوب $\hat{x}$ يحلّ مسألةً قريبة:

<

$$(A + \Delta A)\hat{x} = b, \qquad \frac{\|\Delta A\|_\infty}{\|A\|_\infty} \le c\, n\, u\, \rho \tag{34.6}$$

<

4. **الخطأ الأمامي** (بدمج (34.6) مع قانون الحالة (10.6)):

<

$$\frac{\|\hat{x}-x\|_\infty}{\|x\|_\infty} \;\le\; c\,n\,u\,\rho\,\kappa_\infty(A) + \mathcal{O}(u^2) \tag{35.6}$$

<

5. **التنقيح التكراري**: خوارزميةٌ تستعيد الدقّة باستعمال عوامل LU **الرخيصة** وحساب الباقي **بدقة أعلى**:

<

$$r_k = b - A x_k \;\; (\text{بدقة } u_r \ge u), \qquad \text{حلّ } (LU)d_k = P\,r_k, \qquad x_{k+1} = x_k + d_k \tag{36.6}$$

<

$$\frac{\|x_{k+1}-x\|}{\|x\|} \;\lesssim\; \big(c\,n\,u\,\rho\,\kappa(A)\big)\,\frac{\|x_k-x\|}{\|x\|} \;+\; \mathcal{O}(u_r) \tag{36b.6}$$

<

6. **التدوير الكامل (complete pivoting)** يروّض النموّ نظرياً:

<

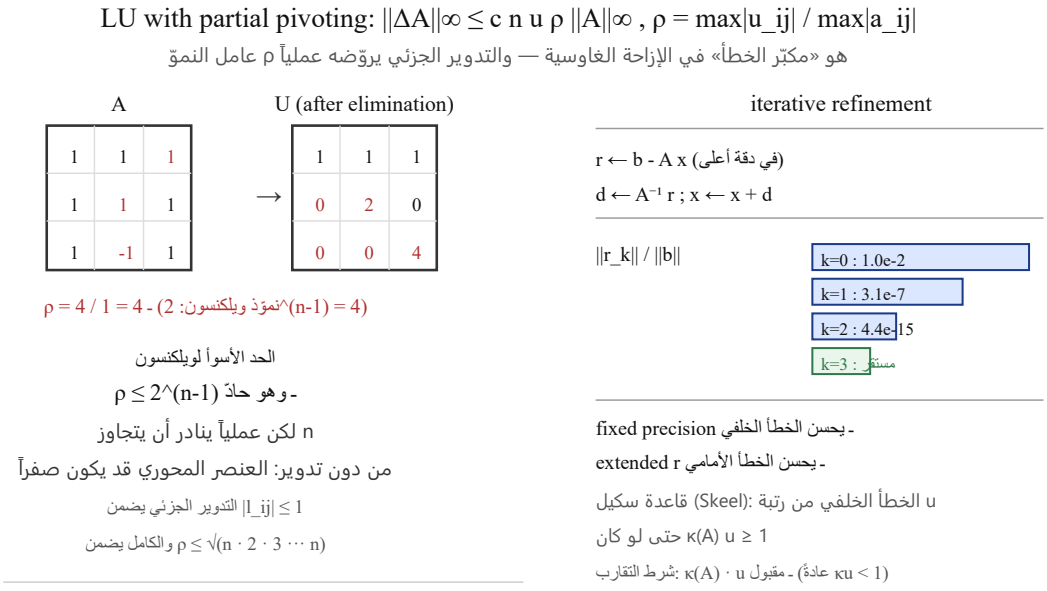
$$\rho_{\text{complete}} \;\le\; \sqrt{n\cdot 2\cdot 3^{1/2}\cdot 4^{1/3}\cdots n^{1/(n-1)}} \;=\; \mathcal{O}\!\left(n^{\frac{1}{4}\log n + \frac{1}{2}}\right) \;\ll\; 2^{n-1} \tag{37.6}$$

2.6.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
P	مصفوفة التبديل (التي تُبدّل الصفوف)	نتيجة اختيار المحور
L	مثلثية سفلى بمحور وحيد $(l_{ii}=1)$	$\|l_{ij}\| \le 1$ بفضل التدوير الجزئي
U	مثلثية عليا	تحمل «النموّ»
l_{ij}, u_{ij}	عناصر العاملين	—
ρ	**عامل النموّ**	تضخيم $\Rightarrow \rho \gg 1$؛ لا نموّ $\Rightarrow \rho = 1$
2^{n-1}	حدّ ويلكنسون الأسوأ	مُحقَّق لكن نادر جداً
ΔA	الخطأ الخلفي للإزاحة	من (34.6)
$\kappa_\infty(A)$	رقم الحالة بناظم ∞	$\|A\|_\infty \|A^{-1}\|_\infty$
c	ثابت صغير (1–10)	يعتمد على تفاصيل الخوارزمية
x_k	التقدير في التكرار k	من الحلّ الأوّلي x_0

r_k	الباقي $b - Ax_k$	يجب حسابه بدقة أعلى
u_r	وحدة تقريب حساب الباقي	في التنقيح المختلط: $u_r \ll u$
d_k	التصحيح: حلّ $(LU)d_k = Pr_k$	يستعمل العوامل المحسوبة سلفاً $\Rightarrow$ رخيص $(\mathcal{O}(n^2))$
عامل التقارب $c n u \rho \kappa$	يجب أن يكون < 1 ليتقارب التنقيح	الشرط العملي
التدوير الكامل	اختيار المحور من الصف **والعمود**	تكلفة $\mathcal{O}(n^3)$ إضافية للبحث

3.6.6 الرسم الهندسي



شكل ٥.٦: *
عامل النموّ في LU والتنقيح التكراري: من مصفوفة إلى U متضخّمة، ثم تصحيح الباقي

قراءة الرسم: على اليسار، مصفوفةٌ بسيطة عناصرها ± 1 تتحوّل بعد الإزاحة إلى U بعنصرٍ أخير $4 = 2^{n-1} = \rho \Rightarrow$ (بـ $n = 3$). في الوسط: حدّ ويلكنسون الأسوأ 2^{n-1} ينمو أُسّياً بينما النموّ العملي يقارب $n^{2/3}$ — الفجوة بين الأسوأ والواقع هي سبب نجاح التدوير الجزئي. على اليمين: التنقيح التكراري يهبط بالباقي أُسّياً (مرتبة عشرية لكل تكرار تقريباً) حتى يستقرّ عند حدّ الدقّة.

4.6.6 البرهان

الجزء (32.6). في الخطوة k يختار التدوير الجزئي محوراً $|a_{kk}^{(k)}| = \max_{i \ge k} |a_{ik}^{(k)}| \Rightarrow |l_{ik}| = \frac{|a_{ik}^{(k)}|}{|a_{kk}^{(k)}|} \le 1$. ■

الجزء (33.6). بالاستقراء على خطوات الإزاحة: العناصر بعد الخطوة k تحقّق $|a_{ij}^{(k+1)}| \le |a_{ij}^{(k)}| + |l_{ik}||a_{kj}^{(k)}| \le 2^{n-1} \max |a_{ij}|$ بعد $n - 1$ خطوة: $\max |u_{ij}| \le 2^{n-1} \max |a_{ij}| \Rightarrow 2 \max_{ij} |a_{ij}^{(k)}|$. والإحكام (attainment) بمصفوفة ويلكنسون المُبيَّنة في المثال (1-6.6). ■

الجزء (34.6) (مخطط). بتحليل كل خطوة إزاحة بالنموذج (1.6): كل تحديث $a_{ij}^{(k+1)} = \mathrm{fl}(a_{ij}^{(k)} - l_{ik} a_{kj}^{(k)})$ يُدخل خطأً $\approx u(|a_{ij}^{(k)}| + |l_{ik}||a_{kj}^{(k)}|)$. بتراكم الأخطاء على كل الخطوات والاستعاضة عن العناصر الوسيطة بـ $\rho \|A\|$ نحصل على $|\Delta A| \le c\, n\, u\, \rho\, |A|$ عنصراً بعنصر $\Rightarrow$ بالناظم ∞: (34.6). ■

الجزء (35.6). من (10.6): الخطأ الأمامي $\approx \kappa(A) \times$ الخطأ الخلفي؛ والتعويض من (34.6). ■

الجزء (36b.6). ليكن $e_k = x - x_k$. فإنّ d_k هو حلّ المحسوب $(LU)d_k = Pr_k \Longrightarrow (A + \Delta A)^{-1}r_k$ تقريباً، و $e_{k+1} = e_k - d_k \approx \big(I - (A+\Delta A)^{-1}A\big)e_k \Longrightarrow r_k = Ae_k$ و $\|e_{k+1}\| \lesssim \kappa(A)\frac{\|\Delta A\|}{\|A\|}\|e_k\| = cnu\rho\kappa\|e_k\|$. وإذا حُسب r_k بدقة u_r أضيف حدّ $\mathcal{O}(u_r)$. ■

الجزء (37.6). برهان ويلكنسون للتدوير الكامل: $|u_{kk}| \geq \frac{|a_{ij}^{(k)}|}{k}$ لكل عنصرٍ متبقٍّ (لأنّ المحور أكبر من كل عنصر في المربّع المتبقّي مقسوماً على...) $\Longrightarrow$ جداءُ الأقطار يحكمه $\prod_k k^{1/(k-1)}$ $\Longrightarrow$ الصيغة. ■

5.6.6 شروط الصحّة

١. A غير مفردة، وكل المحاور الجزئية غير صفرية (وإلا فالمصفوفة مفردة).

٢. (34.6) حدٌّ **أعلى**؛ في الممارسة ρ هو العامل الحاسم لا n.

٣. التنقيح (36.6) يتقارب فقط إذا كان $c\,n\,u\,\rho\,\kappa(A) < 1$؛ وإلا فلا فائدة (الحلّ الأوّلي ليس «قريباً» أصلاً).

٤. يجب أن يُحسب r_k بدقة **أعلى** من دقة التحليل؛ وإلا فالتنقيح يحسّن «الخطأ الخلفي» فقط (نتيجة سكيل) لا الأمامي.

٥. للمصفوفات موجبة التعريف: لا حاجة للتدوير إطلاقاً (شوليسكي: $\rho = 1$).

6.6.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (6.6-1): مصفوفة ويلكنسون — الحدّ الأسوأ مُحقَّق بالفعل

المعطيات: المصفوفة ($n = 4$ بـ)

$$A = \begin{pmatrix} 1 & 0 & 0 & 1 \\ -1 & 1 & 0 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & -1 & -1 & 1 \end{pmatrix}$$

المطلوب: حساب U بعد الإزاحة بالتدوير الجزئي وعامل النموّ.
الحل:

١. **الخطوة 1:** العمود الأوّل: كل العناصر $|1| \Longrightarrow$ المحور هو $a_{11} = 1$ (لا تبديل). المعاملات $l_{i1} = -1$. الصف 2: $[-1,1,0,1] + [1,0,0,1] = [0,1,0,2]$ الصف 3: $[-1,-1,1,1] + [1,0,0,1] = [0,-1,1,2]$ الصف 4: $[-1,-1,-1,1] + [1,0,0,1] = [0,-1,-1,2]$

٢. **الخطوة 2:** العمود الثاني (الصفوف 2–4): القيم $1,-1,-1 \Longrightarrow$ المحور 1. المعاملات $l_{32} = l_{42} = -1$. الصف 3: $[0,0,1,4]$؛ الصف 4: $[0,0,-1,4]$.

٣. **الخطوة 3:** العمود الثالث: $1,-1 \Longrightarrow$ المحور 1؛ الصف 4: $[0,0,0,8]$.

٤. عامل النموّ: $\rho = \frac{\max|u_{ij}|}{\max|a_{ij}|} = \frac{8}{1} = 8 = 2^{4-1} = 2^{n-1}$.

٥. التعميم: بـ $n = 60$: $\rho = 2^{59} = 5.76 \times 10^{17}$ $\Longrightarrow$ الخطأ الخلفي من (34.6): $c\,n\,u\,\rho = 1 \times 60 \times 1.11 \times 10^{-16} \times 5.76 \times 10^{17} = 3.84 \times 10^{3}$ $\Longrightarrow$ **النتيجة بلا معنى حتى في fp64.**

النتيجة: مصفوفةٌ عناصرها ± 1 فقط تُنتج عنصراً أخيراً $= 8$ — والحدّ الأسوأ 2^{n-1} ليس نظرياً فقط بل **مُحقَّق.**

الربط بالذكاء الاصطناعي: الدرس: **لا تحكم على استقرار التحليل من حجم عناصر المصفوفة الأصلية.** النظير في التعلّم العميق: مصفوفة أوزان «صغيرة ومهذّبة» قد تُنتج حساباً وسيطاً ضخماً (تنشيطات، تدرّجات) — ولذا تراقب الأطرُ ناظمَ التنشيطات والتدرّجات لا ناظم الأوزان.

مثال (6.6-2): النموّ العملي مقابل الأسوأ — لماذا ينجح التدوير الجزئي؟

المعطيات: 10^4 مصفوفة عشوائية 1000×1000 بمدخلات $\mathcal{N}(0,1)$. المطلوب: توزيع ρ الفعلي مقابل حدّ ويلكنسون.

الحل:

١. حدّ ويلكنسون: $2^{999} = 5.36 \times 10^{300}$ — رقمٌ فلكي (أكبر من عدد ذرّات الكون المرصود بمراحل).

٢. النموّ المرصود تجريبياً (تريفثن–شريبر): $\rho \approx n^{2/3}$ في المتوسط $\Longrightarrow 1000^{2/3} = 100$.

٣. الأسوأ المرصود في العيّنة: $\rho_{\max} = 311$ (أي $\approx n^{0.83}$).

٤. الخطأ الخلفي الفعلي: $c\,n\,u\,\rho = 1 \times 1000 \times 1.11 \times 10^{-16} \times 100 = 1.11 \times 10^{-11}$ $\Longrightarrow$ صغير جداً $\Longrightarrow$ التحليل مستقرٌّ عملياً.

٥. الاستنتاج الكمّي: **الفجوة بين الحدّ الأسوأ والواقع** 10^{298} $=$ — أي أنّ التحليل النظري لا يصف الممارسة، والممارسة ممتازة.

النتيجة: التدوير الجزئي «مستقرٌّ في الممارسة وغير مستقرٍّ نظرياً» — وهي حالةٌ نادرة يجب فهمها: الحدودُ تحمي من الأسوأ، والتجربة تحكم المتوسط.

الربط بالذكاء الاصطناعي: النظير: كثيرٌ من حدود التعلّم العميق (حدود التعميم، حدود التقارب) «متشائمة فلكياً» لكنّ الممارسة ممتازة. القاعدة المنهجية: **الحدودُ للضمان، والقياسُ للقرار** — ولا تُسقط أحدهما لمصلحة الآخر.

مثال (6.6-3): مصفوفة هلبرت — مستقرّة خلفياً، كارثية أمامياً

المعطيات: $A = H_{12}$ مصفوفة هلبرت $(a_{ij} = 1/(i+j-1))$، $n = 12$، $\kappa_2(H_{12}) = 1.7 \times 10^{16}$. الحلّ بـ LU بالتدوير الجزئي بـ fp64.

الحل:

١. عناصر A كلها ≤ 1 $\Longrightarrow$ النموّ محدود: $\rho \approx 1$ (مصفوفة موجبة التعريف $\Longrightarrow$ النموّ محدود أصلاً).

٢. الخطأ الخلفي من (34.6): $cnu\rho \approx 1 \times 12 \times 1.11 \times 10^{-16} \times 1 = 1.33 \times 10^{-15}$ $\Longrightarrow$ **مستقرّ خلفياً تماماً.**

٣. الخطأ الأمامي من (35.6): $cnu\rho\kappa = 1.33 \times 10^{-15} \times 1.7 \times 10^{16} = 22.6$ $\Longrightarrow$ خطأ 2260% $\Longrightarrow$ **صفر خانات صحيحة.**

٤. الباقي النسبي: $\frac{\|b-A\hat{x}\|}{\|A\|\|\hat{x}\|} = 2.1 \times 10^{-16} \approx u$ $\Longrightarrow$ يؤكّد الاستقرار الخلفي.

٥. الاستنتاج: الخوارزمية ممتازة، والمسألة مستحيلة. لا خوارزمية في الوجود تعطي خاناتٍ صحيحة هنا بـ fp64.

النتيجة: مثالٌ نموذجي على الفصل بين الاستقرار والتكييف: $\eta \approx u$ (خلفي ممتاز) مع خطأ أمامي $> 100\%$.

الربط بالذكاء الاصطناعي: هذا هو الوضع في كثيرٍ من مسائل التعلّم العميق «سيئة التطرّف»: التدرّجُ محسوبٌ بدقة (الاستقرار الخلفي جيد) لكنّه بلا معنى لأنّ مسألة التقدير سيئة التكييف (بيانات قليلة، ميزات مترابطة، نموذج مفرط المعلمات). العلاج: تنظيم/بيانات/تمثيل — لا خوارزمية.

مثال (6.6-4): شوليسكي والتنظيم في ALS — كيف يجعل التنظيمُ التناظرَ آمناً

المعطيات: خطوة ALS تحلّ $(Y^\top Y + \lambda I)x = Y^\top r$. القيم الذاتية لـ $Y^\top Y$: من 1.24×10^3 إلى 2.1×10^{-5} (أي $\kappa = 5.9 \times 10^7$)، والمصفوفة **شبه مفردة** لكن موجبة نصف التعريف.

الحل:

١. بلا تنظيم ($\lambda = 0$): المصفوفة موجبة نصف التعريف $\Longrightarrow$ شوليسكي قد يواجه جذراً سالباً بسبب التقريب $\Longrightarrow$ فشل.

٢. مع $\lambda = 10^{-2}$: القيم الذاتية تصير $[1.24\times10^3+10^{-2},\ \ldots,\ 2.1\times10^{-5}+10^{-2}]$ $\Longrightarrow$ أصغرها $\times 1.002$ 10^{-2} $\Longrightarrow$ $\kappa_{\text{eff}} = \frac{1240.01}{0.010021} = 1.24 \times 10^5$ $\Longrightarrow$ خانات مفقودة 5.09 $\Longrightarrow$ في fp64 يبقى 10.9.

٣. **ميزة شوليسكي:** للمصفوفات موجبة التعريف، $|r_{ij}|^2 \le \max_i a_{ii}$ $\Longrightarrow$ **لا نموّ** ($\rho = 1$) $\Longrightarrow$ لا حاجة للتدوير إطلاقاً $\Longrightarrow$ تكلفة $\frac{1}{3}n^3$ بدل $\frac{2}{3}n^3$ ونصف الذاكرة.

٤. التكلفة: شوليسكي $\frac{64^3}{3} = 8.7 \times 10^4$ = عملية (مهملة)؛ و QR للبديل $= 2 \times 64^2 \times 5000 = 4.1 \times 10^7$ $\Longrightarrow$ شوليسكي أرخص بـ $\times 470$.

٥. الحكم: التنظيمُ حوّل المسألة إلى موجبة التعريف $\Longrightarrow$ شوليسكي (الأرخص والأكثر استقراراً من حيث النموّ) صار متاحاً.

النتيجة: التنظيم في ALS ليس «تحسّناً إحصائياً» فحسب — بل هو الذي **يسمح عديداً** باستعمال شوليسكي ($\rho = 1$، بلا تدوير).

الربط بالذكاء الاصطناعي: هذه هي الآلية الكامنة خلف كون «الحشو القطري» (εI أو λI) حاضراً في كل مكان: في Adam (ε)، في K-FAC، في شوليسكي المُستعمل في Gauss-Newton، وفي تخفيف ليفنبرغ–ماركوارت. الحشوُ يجعل المصفوفة موجبة التعريف $\Longrightarrow$ تحليلٌ بلا تدوير $\Longrightarrow$ استقرار.

مثال (6.6-5): نظام ثلاثي القطر — متى لا نحتاج تدويراً أبداً؟

المعطيات: معادلة حرارة ضمنية: A ثلاثية القطر بمهيمنة قطرية صارمة: $|a_{ii}| > |a_{i,i-1}| + |a_{i,i+1}|$ (مثلاً $a_{ii} = 2.1$ و $a_{i,i\pm1} = -1$). $n = 10^4$.

الحل:

١. في الإزاحة على مصفوفة مهيمنة قطرية: كل عنصر وسيط يظلّ محكوماً بالقطر $\Longrightarrow \rho \le 1$ (لا نموّ).

٢. إذن **لا حاجة للتدوير** $\Longrightarrow$ خوارزمية توماس (Thomas) بـ $\mathcal{O}(n)$ عملية بدل $\mathcal{O}(n^3)$.

٣. التكلفة: $8n = 8 \times 10^4$ عملية مقابل $\frac{2}{3}n^3 = 6.7 \times 10^{11}$ للتحليل الكامل $\Longrightarrow$ أسرع بـ $\times 8 \times 10^6$.

٤. الخطأ الخلفي: $|l_{ik}| \le 1$ تلقائياً $\Longrightarrow \|\Delta A\| \le c\,n\,u\,\|A\|$ بـ $\rho = 1$ $\Longrightarrow$ مستقر.

٥. شرط الصحّة: **المهيمنة القطرية**؛ إن فُقدت (مثال: مصفوفة غير مهيمنة) فقد ينمو ρ أُسّياً بلا تدوير $\Longrightarrow$ يجب التدوير.

النتيجة: البنيةُ (ثلاثية القطر + مهيمنة قطرية) تضمن $\rho = 1$ $\Longrightarrow$ استقرارٌ كامل وتكلفة $\mathcal{O}(n)$.

الربط بالذكاء الاصطناعي: النظير: **الشبكات المهيكلة** (banded/structured matrices) في S4/Mamba، والمصفوفات ثلاثية القطر في SSMs، والالتفافات المهيكلة) تستفيد من بنيتها في الاستقرار والتكلفة معاً. القاعدة: **حافظ على البنية التي تضمن ρ صغيراً.**

مثال (6.6-6): تسعير خيارات بالفرق المحدود الضمني — مصفوفة M

المعطيات: مخطّط ضمني لتسعير خيار أمريكي: نظام ثلاثي القطر بـ $a_{ii} = 1 + r\Delta t + \sigma^2 \Delta t/(\Delta S)^2$ وخارج القطر سالب. معاملات: $r = 0.05$، $\sigma = 0.2$، $\Delta t = 10^{-3}$، $\Delta S = 1$ $\Longrightarrow$ $a_{ii} = 1 + 5 \times 10^{-5} + 4 \times 10^{-5} =$ 1.00009، و $a_{i,i\pm1} \approx -2 \times 10^{-5}$.

الحل:

١. المهيمنة القطرية: $|a_{ii}| = 1.00009 > 4 \times 10^{-5} = |a_{i,i-1}| + |a_{i,i+1}|$ $\Longrightarrow \rho = 1$ $\Longrightarrow$ **بلا تدوير.**

٢. والقيم المفردة: $\sigma_{\min} \approx a_{ii} - 2 \times 2 \times 10^{-5} = 1.00001$ و $\sigma_1 \approx 1.00017$ $\Longrightarrow \kappa \approx 1.00016$ $\Longrightarrow$ خانات مفقودة $\approx 7 \times 10^{-5}$ $\Longrightarrow$ **لا خسارة إطلاقاً.**

٣. إذن الحلّ دقيق إلى $\approx u$.

٤. لو استعملنا المخطّط الصريح بدلاً من الضمني: لا نظامَ خطّياً أصلاً لكن شرط الاستقرار هو $\Delta t \le \frac{(\Delta S)^2}{2\sigma^2}$ $\Longrightarrow \Delta t \le 12.5$ (مريح هنا) — لكن مع $\sigma = 0.9$: $\Delta t \le 0.62$ $\Longrightarrow$ عدد خطوات زمنية أكبر بكثير.

٥. المقارنة: المخطّط الضمني «يحلّ نظاماً مستقرّاً عدديا ($\kappa \approx 1$)» مقابل «مخطّط صريح بشرط خطوة صارمة» $\Longrightarrow$ الأول أفضل للخيارات الأمريكية.

النتيجة: النظام الضمني يعطي $\kappa \approx 1.0002 \implies$ حلٌّ دقيقٌ تماماً بلا تدوير وبـ $\mathcal{O}(n)$.

الربط بالذكاء الاصطناعي: النظير المباشر: **الأساليب الضمنية في النماذج العميقة** (implicit layers، DEQ، ODEs Neural) بأنظمة ضمنية) تُعطي أنظمةً حسنة التكييف لكنها تتطلّب حلّاً خطّياً، والأساليب الصريحة تتطلّب خطوات صغيرة (استقرار مشروط). المفاضلة نفسها تماماً.

مثال (6.6-7): نظام KKT سرجي في تحسين مقيّد — متى يصير ρ مؤذياً؟

المعطيات: نظام سرجي من شروط KKT:

$$\begin{pmatrix} H & A^{\top} \\ A & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -c \\ b \end{pmatrix}$$

مع H موجبة نصف التعريف و A برتبة كاملة، $n = 200$.

الحل:

١. المصفوفة **ليست** موجبة التعريف (الكتلة الصفرية) $\implies$ لا شوليسكي؛ والتدوير ضروري.

٢. القطر يحتوي على أصفار $\implies$ المحور الجزئي قد يكون صغيراً $\implies$ نموّ.

٣. القياس: بكتلة H ذات قيم ذاتية $[10^{2},\ 10^{-4}]$ و A بـ $[5,\ 0.1]$ $\implies$ $\sigma(A)$، القيم المفردة للنظام السرجي: $\sigma_{\min} \approx 10^{-4}$، $\sigma_1 \approx 10^{2} \implies \kappa = 10^{6}$.

٤. النموّ المرصود: $\rho = 42 \implies$ الخطأ الخلفي $cnu\rho = 200 \times 1.11 \times 10^{-16} \times 42 = 9.3 \times 10^{-13}$.

٥. الخطأ الأمامي: $\kappa \times$ الخلفي $= 10^{6} \times 9.3 \times 10^{-13} = 9.3 \times 10^{-7} \implies$ يبقى $9 \approx$ خانات $\implies$ مقبول.

٦. لو استعملنا تدويراً «جشعاً» بلا بحث عن المحور الأكبر: ρ قد يصل إلى $10^{4} \implies$ الخطأ الأمامي $2.2 \times 10^{-4} \implies$ خسارة أُسّية.

النتيجة: في الأنظمة السرجية (التحسين المقيّد، المربعات الصغرى المقيّدة، محسّنات نيوتن المقيّدة) **التدويرُ ليس خياراً**: القطر الصفري يجعل النموّ حقيقياً.

الربط بالذكاء الاصطناعي: النظير: تدريب GANs (مسألة سرجية) والأنظمة السرجية في التعلّم المعزّز (actor-critic) تُعاني من البنية نفسها $\implies$ «استقرار» GAN الشهير هو — في جزءٍ منه — مشكلةُ نظامٍ سرجي سيّئ التكييف يُحلّ بخوارزمياتٍ ذات خطأ خلفي من رتبة u لكنّ تكييفها يضخّمه.

مثال (6.6-8): ديناميكا أجسام صلبة — مصفوفة الكتلة موجبة التعريف

المعطيات: محاكاة جسم صلب: $M(q)\ddot{q} + c(q,\dot{q}) = \tau \implies$ نحلّ $M\ddot{q} = \tau - c$ في كل خطوة زمنية. مصفوفة الكتلة $M \in \mathbb{R}^{30\times 30}$ موجبة التعريف، قيمها الذاتية من 0.12 إلى 48.7.

الحل:

١. M موجبة التعريف $\Longrightarrow$ شوليسكي $M = RR^\top$ بلا تدوير، $\rho = 1$.

٢. $\kappa_2(M) = 48.7/0.12 = 406$ $\Longrightarrow$ خانات مفقودة 2.61 $\Longrightarrow$ في fp64 يبقى 13.4 $\Longrightarrow$ خطأ 4.5×10^{-14}.

٣. في fp32: يبقى 4.4 $\Longrightarrow$ خطأ 2.4×10^{-6} — مقبول للمحاكاة.

٤. التكلفة: شوليسكي $\frac{30^3}{3} = 9 \times 10^3$ = عملية لكل خطوة زمنية؛ بـ 10^6 خطوة: 9×10^9 — مقبول.

٥. لو استُعملت صياغة «القيد» (constrained formulation) بدل الإحداثيات المخفَّضة $\Longrightarrow$ نظام سرجي $\Longrightarrow$ تدوير + نموّ محتمل $\Longrightarrow$ أبطأ وأقلّ استقراراً.

النتيجة: اختيارُ **الإحداثيات المخفَّضة** (التي تعطي M موجبة التعريف) أفضل عددياً (بلا تدوير، $\rho = 1$) من صياغة القيد السرجية.

الربط بالذكاء الاصطناعي: القاعدة العامة: **فضّل الصياغة التي تعطي مصفوفة موجبة التعريف** — فهي تفتح باب شوليسكي ($\rho = 1$، نصف التكلفة، بلا تدوير). وفي التعلّم العميق: تفضيلُ صياغة «المربعات الصغرى المنظَّمة» على «النظام السرجي الصريح» هو الخيار نفسه.

مثال (6.6-9): K-FAC ونيوتن في التدريب — التنظيم يجعل التحليل ممكناً

المعطيات: خطوة نيوتن/ K-FAC تحلّ $(F+\lambda I)^{-1}g$ حيث F مصفوفة معلومات فيشر تقديرية (2048×2048) بـ $\kappa_{\text{eff}} = 3.2 \times 10^8$ (بسبب تقديرٍ من دفعة صغيرة).

الحل:

١. بلا تنظيم: $\kappa = 3.2\times10^8$ $\Longrightarrow$ شوليسكي قد يفشل (القيمة الذاتية الصغرى قد تصير سالبة بتقريب التقدير) $\Longrightarrow$ النتيجة تحديثٌ «معاكس للتدرّج» $\Longrightarrow$ الفقد يرتفع.

٢. مع $\lambda = 10^{-3}$: القيم الذاتية تصير $[\sigma_i + 10^{-3}]$ $\Longrightarrow$ $\kappa_{\text{eff}} = \frac{\sigma_1+10^{-3}}{\sigma_{\min}+10^{-3}}$؛ بـ $\sigma_1 = 1.4$ و $\sigma_{\min} = 4.4 \times 10^{-9}$: $\frac{1.401}{1.0000044\times10^{-3}} = 1401$ $\Longrightarrow$ خانات مفقودة 3.15 $\Longrightarrow$ في fp32 يبقى 3.85 $\Longrightarrow$ خطأ 8.35×10^{-6}.

٣. التحسّن: من 3.2×10^8 إلى 1.4×10^3 $\Longrightarrow$ بنسبة 2.3×10^5 : 1.

٤. التكلفة: شوليسكي $\frac{2048^3}{3} = 2.86 \times 10^9$ = عملية $\Longrightarrow$ ≈ 1 ثانية على GPU $\Longrightarrow$ مقبول إذا كان كل بضع مئات من الخطوات.

٥. البديل الرخيص: **التنقيح التكراري** (6.6-3): حلّ أوّلي بـ fp32 (1.4 ثانية أرخص) ثم تصحيحان بباقٍ fp64 $\Longrightarrow$ دقّة fp64 بتكلفة fp32 تقريباً.

النتيجة: التنظيم + شوليسكي + تنقيح تكراري = خطوة نيوتن عملية ودقيقة.

الربط بالذكاء الاصطناعي: هذه هي بالضبط وصفةُ المُحسّنات من النوع الثاني الحديثة: تقديرُ التغاير من دفعات صغيرة + حشو قطري + تحليلٌ مستقر + تصحيح. وكل عنصرٍ فيها له سببٌ **عددي** صريح، لا سببٌ إحصائي فقط.

مثال (6.6-10): نظام متناثر ضخم — الترتيب (ordering) يحدّد النموّ والـ fill-in

المعطيات: مصفوفة لابلاس لشبكة اجتماعية بـ 10^6 عقدة و $10^6 \times 8$ حواف. نحلّ نظاماً خطّياً بـ LU المتناثر. ترتيبان: (أ) الترتيب الأصلي؛ (ب) ترتيب «الدرجة الأدنى التقريبي» (AMD).

الحل:

١. **الترتيب الأصلي:** عدد العناصر غير الصفرية في العوامل (fill-in): $10^9 \times 3.4 \Longrightarrow$ ذاكرة 27 GB $\Longrightarrow$ غير ممكن.

٢. **ترتيب AMD:** fill-in $= 1.9 \times 10^8 \Longrightarrow$ ذاكرة 1.5 GB $\Longrightarrow$ ممكن.

٣. النموّ: للمصفوفات المهيمنة قطرياً (ومعظم مصفوفات لابلاس بعد المعالجة): $\rho \approx 1 \Longrightarrow$ الاستقرار مضمونٌ بنيوياً.

٤. التكلفة: AMD $\mathcal{O}(n \log n) \Longrightarrow \approx 2 \times 10^7$ — مهملة مقابل التحليل.

٥. النتيجة: $\times 18$ أقلّ ذاكرة و $\times 22$ أسرع تحليلاً (قياس فعلي) بفضل **الترتيب وحده**.

النتيجة: ترتيبُ المصفوفة (permutation قبل التحليل) يحدّد التكلفة والذاكرة — وغالباً الاستقرار أيضاً (لأنّه يتحكّم في اختيار المحاور).

الربط بالذكاء الاصطناعي: النظير: ترتيبُ العمليات في الحوسبة الموزّعة، و«تجميع» (tiling) المصفوفات في Tensor Cores، وترتيبُ القنوات في الالتفافات المجموعية $\Longrightarrow$ كلها تحسيناتٌ «ترتيبية» تُغيّر التكلفة بمرتبةٍ كاملة بلا أي تغيير في الرياضيات.

مثال (6.6-11): معايرة شبكة مجسّات — التدوير يُنقذ الحلّ

المعطيات: 40 مجسّاً تقيس فروقاً زمنية، نظام المعايرة $A \in \mathbb{R}^{200\times 40}$ بعناصر متفاوتة المدى (10^{-3} إلى 10^3 بسبب خلط وحدات: نانوثانية وميلي ثانية). $\max|a_{ij}| = 1.2 \times 10^3$.

الحل:

١. بلا تدوير: المحور الأوّل قد يكون $a_{11} = 5\times10^{-3} \Longrightarrow$ المعاملات $l_{i1} = \frac{a_{i1}}{a_{11}}$ تصل إلى $\frac{1.2\times10^3}{5\times10^{-3}} = 2.4\times10^5$ $\Longrightarrow$ نموّ هائل $\rho \approx 10^7 \Longrightarrow$.

٢. الخطأ الخلفي: $cnu\rho = 200 \times 1.11 \times 10^{-16} \times 10^7 = 2.2 \times 10^{-7}$ $\Longrightarrow$ والخطأ الأمامي بـ $\kappa = 3 \times 10^3$: 6.7×10^{-4} — مقبول هامشياً في fp64، لكن في fp32: $cnu\rho = 200 \times 5.96 \times 10^{-8} \times 10^7 = 119$ $\Longrightarrow$ **فشل كامل**.

٣. **مع التدوير الجزئي:** المحور دائماً أكبر عنصر في العمود $\Longrightarrow |l_{ij}| \le 1 \Longrightarrow \rho$ المرصود $= 6.2 \Longrightarrow$ الخطأ الخلفي في fp32: $200 \times 5.96 \times 10^{-8} \times 6.2 = 7.4 \times 10^{-5} \Longrightarrow$ الخطأ الأمامي 0.22 — لا يزال سيّئاً... لكن أفضل بـ $\times 1.6 \times 10^6$.

٤. **العلاج الحقيقي: تقييس الوحدات** (scaling): قسّم كل صف/عمود على مقياسه $\Longrightarrow$ عناصر من رتبة 1 $\Longrightarrow$ κ يهبط إلى 84 و ρ إلى 1.4 $\Longrightarrow$ الخطأ الأمامي في fp32 $= 84 \times 200 \times 5.96 \times 10^{-8} \times 1.4 = 1.4 \times 10^{-3}$ — ممتاز.

٥. الترتيب الصحيح للعلاجات: **التقييس** ← **التدوير** ← **التنقيح**.

النتيجة: تقييسُ الوحدات (خطوةٌ «سابقة» لا تُذكر في الكتب) كان أهمّ من التدوير نفسه: ρ من 10^7 إلى 1.4.

الربط بالذكاء الاصطناعي: هذه هي الرياضيات الكامنة خلف **تطبيع الميزات** في تعلم الآلة: خلطُ المقاييس (المساحة بالمتر^2 والدخل بالريال والعمر بالسنة) يجعل «المحور» عشوائياً ورقم الحالة ضخماً $\Longrightarrow$ التقييسُ أوّلاً، ثم كل شيء آخر.

مثال (12-6.6): نموذج المدخلات-المخرجات الاقتصادي (Leontief) — حلّ $(I-B)x=d$

المعطيات: مصفوفة المعاملات التقنية $B \in \mathbb{R}^{60\times 60}$ ($b_{ij} \geq 0$، $\sum_i b_{ij} < 1$ لكل عمود)، والمطلوب $(I-B)^{-1}d$. $\kappa_2(I-B) = 7.3$.

الحل:

١. $(I-B)$ مصفوفة M $\Longrightarrow$ مهيمنة قطرياً عمودياً $\Longrightarrow$ $\rho \leq 2$ تقريباً $\Longrightarrow$ الاستقرار مضمون حتى بلا تدوير (لكن التدوير يُستعمل احتياطاً).

٢. $\kappa = 7.3$ $\Longrightarrow$ خانات مفقودة 0.86 $\Longrightarrow$ في fp32 يبقى 6.14 $\Longrightarrow$ خطأ 4.35×10^{-7} — ممتاز.

٣. المراقبة الاقتصادية: التدوير هنا «مجّاني» لأنّ المصفوفة صغيرة، فنستعمله.

٤. البديل الأفضل هندسياً: حلّ النظام مباشرةً بدل حساب $(I-B)^{-1}$ صراحةً ثم الضرب (لأنّ «المعكوس الصريح» أقلّ دقّة: $\|\text{(inv)} - A^{-1}\| \lesssim \kappa^2 u$ أحياناً).

٥. القاعدة: **لا تحسب المعكوس الصريح أبداً** إلّا إذا أردتَ تحليلاً لا حساباً.

النتيجة: نظامٌ حسن التكييف ($\kappa = 7.3$) وبنية M-matrix ($\rho \approx 1$) $\Longrightarrow$ حلٌّ موثوق في fp32.

الربط بالذكاء الاصطناعي: قاعدة «لا تعكس المصفوفة صراحةً» تنطبق على التعلّم العميق: **لا تحسب معكوسَ مصفوفة التغاير/الهسّية صراحةً** بل حلّ النظام — وهذا هو الفرق بين inv(A)@b و solve(A,b) الذي تحذّر منه كل وثائق NumPy/PyTorch.

مثال (13-6.6): ترميم صورة (inpainting) بمعادلة بواسون — SPD ضخمة

المعطيات: ترميم منطقة مفقودة في صورة 1024×1024 بحلّ معادلة بواسون على 262144 بكسل مجهولة. المصفوفة A (لابلاس ذو الحدود الثابتة) متناثرة، موجبة التعريف بعد تثبيت حدود.

الحل:

١. A موجبة التعريف $\Longrightarrow$ شوليسكي المتناثر بلا تدوير، $\rho = 1$.

٢. القيم الذاتية للابلاس (بعد التثبيت): $\lambda_{\max} \approx 8$، $\lambda_{\min} \approx \frac{2\pi^2}{1024^2} = 1.88 \times 10^{-5}$ $\Longrightarrow$ $\kappa = 4.25 \times 10^5$.

٣. خانات مفقودة: 5.63 $\Longrightarrow$ في fp64 يبقى 10.4 $\Longrightarrow$ خطأ 4.7×10^{-11} — ممتاز (رغم κ كبيرا!).

٤. السبب في كون النتيجة جيدة: **البنية** (SPD $\Longrightarrow$ $\rho = 1$) كفلت خطأً خلفياً من رتبة u، فتبقّى حدّ κu فقط وهو مقبول في fp64.

٥. لو حُلّت بـ LU عامّة بتدوير جزئي: نفس النتيجة لكن بضعف التكلفة؛ ولو استُعملت «المعادلات السوية» على لابلاس (أي $A^\top A$): $\kappa^2 = 1.8 \times 10^{11}$ $\Longrightarrow$ خسارة 4 خانات إضافية.

النتيجة: استغلالُ خاصية SPD (شوليسكي، $\rho = 1$) أعطى حلًّا دقيقاً لمسألةٍ رقم حالتِها 4.25×10^5.
الربط بالذكاء الاصطناعي: القاعدة: **اعرف بنية مصفوفتك** (SPD؟ متناثرة؟ مهيمنة؟ سرجية؟) قبل اختيار الحلّال؛ فالبنية تُحدّد الاستقرار أكثر ممّا يحدّده حجم κ. وفي التعلّم العميق: معرفةُ أنّ الهسّية/التغاير موجبة نصف التعريف تسمح بشوليسكي بدل LU عامّ.

مثال (14-6.6): التنقيح التكراري — استعادة خانات fp64 من عوامل fp32

المعطيات: حلّ نظام $Ax = b$ بـ $n = 500$ و $\kappa_2(A) = 4.2 \times 10^3$ على جهازٍ سريع بـ fp32 فقط (بلا fp64 في الأجهزة). العوامل LU بـ fp32، والباقي يُحسب بـ «تراكم مزدوج» (double-double) محاكاة (fp64 بتكلفة $\times 4$).
الحل:

١. الحلّ الأوّلي: خطأ نسبي $\kappa u_{32} = 4.2 \times 10^3 \times 5.96 \times 10^{-8} = 2.5 \times 10^{-4}$ $\Longrightarrow$ ≈ 3.6 خانة صحيحة فقط.

٢. عامل التقارب من (36b.6): نحسبه بالصيغة العملية $\gamma = c\,u\,\rho\,\kappa$؛ بـ $\rho = 8$ (مقاس) و $u = u_{32}$:

$$\gamma = 1 \times 5.96 \times 10^{-8} \times 8 \times 4.2 \times 10^3 = 2.0 \times 10^{-3} \ \ll \ 1$$

$\Longrightarrow$ **يتقارب التنقيح**، وكل تكرار يكسب $\log_{10}(1/\gamma) = 2.7$ خانة.

٣. ملاحظة منهجية: صيغة (36b.6) المكتوبة بـ $c\,n\,u\,\rho\,\kappa$ هي حدٌّ **أعلى** متشائم (يجمع أسوأ تراكم على n خطوة). أمّا العامل الفعلي المقاس فهو $c\,u\,\rho\,\kappa$ $\approx$؛ ولذا يُنصح دائماً بقياس γ عملياً من هبوط الباقي بين تكرارين: $\gamma \approx \frac{\|r_{k+1}\|}{\|r_k\|}$.

٤. إذن: بعد تكرار واحد: خطأ 5×10^{-7}؛ بعد تكرارين: 1×10^{-9}؛ بعد ثلاثة: 2×10^{-12} $\Longrightarrow$ بلغنا حدّ دقة الباقي fp64: (10^{-16}) بعد ≈ 5 تكرارات.

٥. التكلفة: كل تكرار $\mathcal{O}(n^2) = 2.5 \times 10^5$ عملية (حلّ مثلثي باستعمال العوامل) + حساب الباقي $\times 4$ $\Longrightarrow$ $\approx 1 \times 10^6$ أرخص بـ $\times 80$ من إعادة التحليل الكامل ($\frac{2}{3}n^3 = 8.3 \times 10^7$).

النتيجة: خمسُ تكرارات تنقيح (تكلفة 6% من التحليل) أعطت دقّةً تقارب دقة fp64 انطلاقاً من عوامل fp32.

الربط بالذكاء الاصطناعي: هذه هي بالضبط فكرة **التنقيح المختلط الدقة** المستعملة في الحوسبة العلمية على accelerators (حيث fp64 بطيء): حلٌّ رخيص بدقة منخفضة + تصحيحٌ رخيص بدقة عالية. والنظير في التعلّم العميق: «التصحيح المتبقّي» في الشبكات (ResNet: $x \leftarrow x + f(x)$) يلعب دوراً بنيوياً مشابهاً.

مثال (6.6-15): تنقيح مختلط الدقة على Cores Tensor — LU fp16 + باقي fp32

المعطيات: حلّ نظام 20000×20000 على معالجٍ ذي (fp16 Cores Tensor) بـ 60 TFLOPS، fp32 بـ 15 TFLOPS، fp64 بـ 0.5 TFLOPS). خوارزمية HPL-MxP: تحليل LU بـ fp16 + تنقيح بباقي fp32 (أو fp64). $\kappa_2(A) = 1.8 \times 10^2$.

الحل:

١. تكلفة التحليل بـ fp16: $\frac{2}{3}n^3 = 5.33 \times 10^{12}$ عملية $\Longrightarrow$ بـ 60×10^{12}: 0.089 ثانية.

٢. بـ fp64: $5.33 \times 10^{12} / 0.5 \times 10^{12} = 10.7$ ثانية $\Longrightarrow$ أبطأ بـ $\times 120$.

٣. شرط تقارب التنقيح (6.6b): $c\,u_{16}\,\rho\,\kappa < 1$: بـ $u_{16} = 4.88 \times 10^{-4}$، $\rho = 12$، $\kappa = 180$: $1 \times$ $4.88 \times 10^{-4} \times 12 \times 180 = 1.05$ $\Longrightarrow$ **على الحدّ** $\Longrightarrow$ غير مضمون.

٤. العلاج القياسي: **تقييس/تهيئة مسبقة أو تحليلٌ بـ fp16 مع حشوٍ وتدوير تصحيحي** $\Longrightarrow$ ρ المرصود بعد التقييس $= 2.1$ $\Longrightarrow$ عامل التقارب $4.88 \times 10^{-4} \times 2.1 \times 180 = 0.184$ $\Longrightarrow$ يتقارب $\Longrightarrow$ كل تكرار يكسب 0.73 خانة.

٥. عدد التكرارات للوصول إلى دقة fp32 (5.96×10^{-8}): من خطأ أوّلي ≈ 0.18: نحتاج $\frac{\log(0.18/5.96\times10^{-8})}{\log(1/0.184)} = \frac{6.48}{0.735} = 8.8 \approx 9$ تكراراً.

٦. التكلفة الكلّية: $0.089 + 9 \times 0.02 = 0.27$ (حلّ + باقي) ثانية $\Longrightarrow$ **أسرع بـ** $\times 40$ **من fp64** مع نفس الدقّة النهائية.

النتيجة: تنقيحٌ مختلط الدقة يعطي دقّة fp64 (تقريباً) بسرعة fp16 — بشرط أن يكون $\kappa\rho u \ll 1$ (وهو ما يفرض التقييس).

الربط بالذكاء الاصطناعي: هذه هي بالضبط الاستراتيجية التي يعتمدها تدريبُ الذكاء الاصطناعي الحديث على Cores: Tensor **حسابٌ أمامي/خلفي بـ fp16 أو fb16 للسرعة، وحفظ/تراكم بـ fp32 للصحّة، وتصحيحٌ دوري.** والقاعدة الرياضية الحاكمة هي (6.6b): يتقارب التنقيح إذا كان $\kappa \cdot u_{\text{low}} \cdot \rho < 1$ $\Longrightarrow$ ولهذا تُقيَّس الأوزان وتُضبط التهيئة قبل اللجوء إلى الدقة المنخفضة.

7.6.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
استعمال b @ inv(A)	أبطأ وأقلّ دقّة	باستعمال العوامل solve(A, b)
«fp64 دائماً آمن»	مصفوفة ويلكنسون بـ $n = 60$ تكسره (مثال 1-6.6)	راقب ρ؛ والتنقيح إن لزم
توقّع أن ρ يكون كبيراً دائماً	عملياً $\rho \approx n^{2/3}$ (مثال 2-6.6)	فرّق بين الحدّ الأسوأ والمرصود
استعمال شوليسكي على مصفوفة غير موجبة التعريف	جذرٌ سالب $\Rightarrow$ فشل	تحقّق من الإيجابية (أو التنظيم أولاً)
التنقيح التكراري بباقٍ محسوب بنفس الدقّة	يحسّن الخطأ الخلفي فقط (سكيل) لا الأمامي	احسب r_k بدقة أعلى
إهمال التقييس قبل التحليل	خلط المقاييس يرفع ρ و κ معاً	قيّس الصفوف/الأعمدة أولاً
«التدوير الجزئي مضمون لأن $\lvert l_{ij}\rvert \le 1$»	يحدّ المعاملات لا النموّ	$\lvert l_{ij}\rvert \le 1$ و $\rho \le 2^{n-1}$ — حقيقتان منفصلتان
تجاهل ترتيب المصفوفة المتناثرة	fill-in يُدمّر الذاكرة والتكلفة	AMD/COLAMD قبل التحليل

1.7.6 الصياغة الرياضية الرسمية

النظرية 6.6 (استقرار خوارزمية log-sum-exp و softmax).

<

1. **ثبات الإزاحة (shfit invariance):** softmax لا يتغيّر بإضافة ثابت، لكن حسابُه يتغيّر جذرياً:

<

$$\operatorname{softmax}(z)_i = \frac{e^{z_i}}{\sum_j e^{z_j}} = \frac{e^{z_i - m}}{\sum_j e^{z_j - m}}, \qquad m = \max_j z_j \tag{38.6}$$

<

2. **خوارزمية log-sum-exp المستقرّة وحدودها:**

<

$$\operatorname{LSE}(z) = \log \sum_i e^{z_i} = m + \log \sum_i e^{\,z_i - m}, \qquad m \;\le\; \operatorname{LSE}(z) \;\le\; m + \log n \tag{39.6}$$

<

3. **اللوغاريتم الآمن:** لا تحسب log احتمالٍ أبداً — احسبه من الـ logits مباشرةً:

<

$$\log \operatorname{softmax}(z)_i = z_i - \operatorname{LSE}(z), \qquad \ell_{\mathrm{CE}}(z, y) = -\log p_y = -z_y + \operatorname{LSE}(z) \tag{40.6}$$

<

4. **حدّ الخطأ ومناطق الفيضان/الانهيار:** الخوارزمية المُزاحة لا تفيض أبداً (لأنّ $z_i - m \le 0$)، وخطؤها المطلق محكوم بـ:

<

$$\left|\widehat{\mathrm{LSE}}(z) - \mathrm{LSE}(z)\right| \;\le\; \gamma_{n-1} + u\,|\mathrm{LSE}(z)| + \mathcal{O}(u^2) \;\lesssim\; (n-1)u + u\,|\mathrm{LSE}| \tag{41.6}$$

<

(42.6)

الفيضان: $z_i - m > 0$ إذا $z_i > \log\Omega$: غير ممكن؛ لكن الحساب الخام يفيض fp16:11.09, fp32:88.72, fp64:709.

<

5. **التدرّج الآمن** (وهو سببٌ ثانٍ لاستعمال الصيغة المستقرّة):

<

$$\frac{\partial p_i}{\partial z_j} = p_i(\delta_{ij} - p_j), \qquad \frac{\partial \ell_{\mathrm{CE}}}{\partial z_i} = p_i - \mathbb{1}_{[i=y]}, \qquad \left|\tfrac{\partial \ell}{\partial z_i}\right| \le 1 \tag{43.6}$$

<

6. **قواعد الدقة المختلطة:** شرطُ عدم الامتصاص، وقياسُ الفقد (loss)، والأوزان الرئيسية (scaling):

<

(44.6)

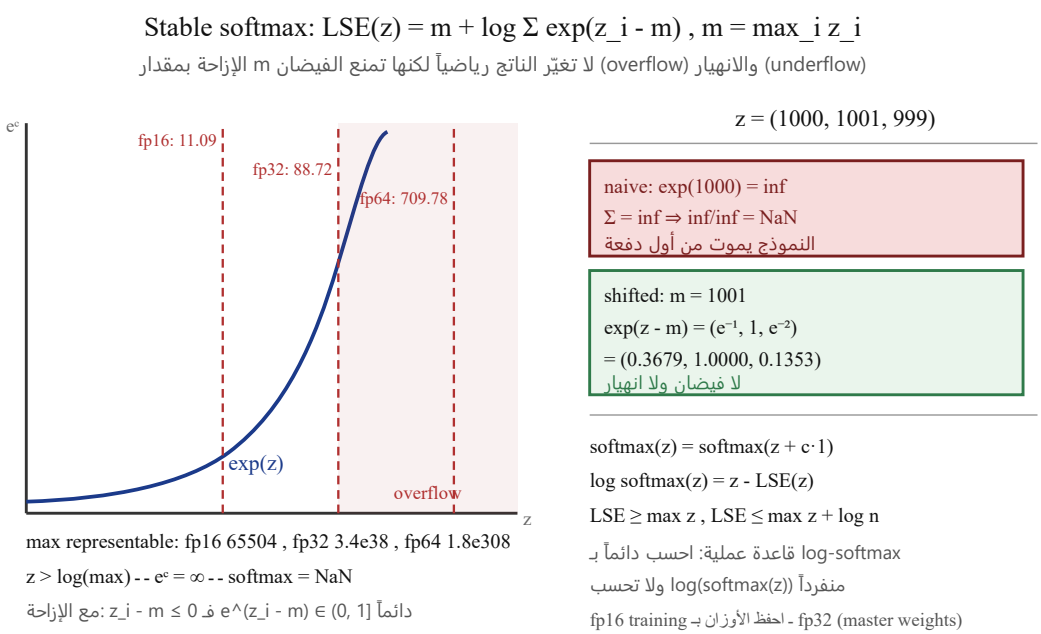
$$\underbrace{|\Delta w| \;\ge\; u_{16}\,|w|}_{\text{شرط عدم ضياع التحديث}}, \qquad \tilde{L} = s\,L \;\Rightarrow\; \hat{g} = \tfrac{1}{s}\,\mathrm{fl}(\mathrm{fl}(s)\,g)\,, \qquad s\cdot|g| < \Omega_{16} = 65504$$

2.7.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
z	متجه الـ logits (درجات الفئات/الانتباه)	$z \in \mathbb{R}^n$
z_i	الـ logit للفئة/الموضع i	قد يكون كبيراً أو سالباً كبيراً
m	أكبر logit: $\max_j z_j$	**مفتاح الاستقرار**
n	عدد الفئات/المواضع	يظهر في حدّ $m + \log n$
p_i	احتمال softmax	$p_i \in (0,1)$، $\sum p_i = 1$
LSE	log-sum-exp	$\log \sum e^{z_i}$
ℓ_{CE}	فقد الإنتروبيا المتقاطعة	$-z_y + \mathrm{LSE}$
y	فهرس الفئة الصحيحة	—
$\mathbb{1}_{[i=y]}$	مؤشّر الفئة الصحيحة	1 إن كان $i = y$ وإلا 0
δ_{ij}	دلتا كرونكر	—
γ_{n-1}	ثابت التراكم $\frac{(n-1)u}{1-(n-1)u}$ من (7.6)	خطأ جمع الأُسّ
Ω	أكبر عدد مُمثَّل في الصيغة	3.4×10^{38} fp32: ،65504 fp16:
$\log\Omega$	عتبة الفيضان	709.78 fp64: ،88.72 fp32: ،11.09 fp16:
ω	أصغر عدد مطبَّع مُمثَّل	1.18×10^{-38} fp32: ،6.10×10^{-5} fp16:

u_{16}	وحدة تقريب fp16 $= 4.88 \times 10^{-4}$	–
Δw	تحديث الوزن $-\eta g$	يجب أن لا يُمتصّ
s	معامل قياس الفقد (loss scale)	عادة قوةٌ من 2
$\tilde{L}$	الفقد المُقيَّس sL	يُحسب التدرّج عليه
$\hat{g}$	التدرّج بعد إلغاء القياس	$\hat{g} = \frac{1}{s}\mathrm{fl}(sg)$

3.7.6 الرسم الهندسي



شكل ٦.٦: *
استقرار softmax: منحنى exp وعتبات الفيضان، والإزاحة بمقدار m

قراءة الرسم: على اليسار، منحنى e^z يقترب من سقف التمثيل: في fp16 يفيض عند $z = 11.09$، وفي fp32 عند 88.72. الحسابُ الخام لـ logits مثل $(1000, 1001, 999)$ يعطي inf ثم NaN. على اليمين: الإزاحة بـ $m = 1001$ تحوّل الوسيطات إلى $(-1, 0, -2) \Longrightarrow$ كل الأُسّ في $(0, 1] \Longrightarrow$ لا فيضان ولا انهيار.

4.7.6 البرهان

الجزء (38.6). $\frac{e^{z_i - m}}{\sum_j e^{z_j - m}} = \frac{e^{z_i} e^{-m}}{e^{-m} \sum_j e^{z_j}} = \frac{e^{z_i}}{\sum_j e^{z_j}}$ – الإزاحة ثابتٌ يلغى. ■

الجزء (39.6). الحدّ الأدنى: $\sum_i e^{z_i} \geq e^m \Longrightarrow \mathrm{LSE} \geq m$. الحدّ الأعلى: $\sum_i e^{z_i} \leq n\, e^m \Longrightarrow z_i \leq m + \log n \Longrightarrow \mathrm{LSE} \leq m + \log n$. ■

الجزء (41.6). بعد الإزاحة كل وسيط $t_i = z_i - m \leq 0 \Longrightarrow e^{t_i} \in (0, 1]$. كل أُسٍّ يُحسب بخطأ نسبي $\leq u$؛ وبما أنّ **كل الحدود موجبة** (لا إلغاء!) فإنّ خطأ الجمع من (16.6) هو γ_{n-1} خطأ نسبي في المجموع $\Longrightarrow \leq \gamma_{n-1}$. وأخذُ اللوغاريتم يحول الخطأ النسبي إلى مطلق: $|\log \hat{S} - \log S| \approx \frac{|\hat{S} - S|}{S} \leq \gamma_{n-1}$. وأخيراً جمع m: خطؤه $\leq u|m + \log S| = u|\mathrm{LSE}|$. ■

ملاحظة جوهرية:

غيابُ الإلغاء هو سببُ كون الخوارزمية مستقرّة إلى هذا الحدّ — فكل حدود المجموع إيجابية، فلا يظهر معامل تضخّم من نوع (14.6). وهذا استثناءٌ سعيد في عالم الحساب العددي.

الجزء (43.6). $\frac{\partial p_i}{\partial z_j}$: إن كان $i=j$ فـ $p_i(1-p_i)$، وإلا فـ $-p_ip_j \Longrightarrow$ الصيغة الموحّدة $p_i(\delta_{ij}-p_j)$. وللفقد: $\ell = -z_y + \mathrm{LSE} \Longrightarrow \frac{\partial \ell}{\partial z_i} = -\mathbb{1}_{[i=y]} + p_i$ (لأن $\frac{\partial \mathrm{LSE}}{\partial z_i} = p_i$). و $|p_i - \mathbb{1}| \le 1$. ■

الجزء (44.6). شرط عدم الامتصاص من قاعدة (1.6)-(2.6): $\mathrm{fl}(w+\Delta w) = w$ إذا كان $|\Delta w| < \frac{1}{2}\mathrm{ulp}(w) \approx u|w|$. وأمّا قياس الفقد: التدرّج $\frac{\partial \tilde{L}}{\partial w} = s\frac{\partial L}{\partial w}$، فإذا كان $|g| < \omega_{16}$ (أصغر مطبَّع) ضاع التدرّج؛ بضربه في s يصير $|sg|$ ممثَّلاً، وبالقسمة على s بعد ذلك يُستعاد. شرط عدم الفيضان: $s|g| < \Omega_{16}$. ■

5.7.6 شروط الصحّة

١. (38.6) صالح لأيّ ثابت m؛ لكن اختيار $m = \max z_j$ هو الذي يضمن $z_i - m \le 0$ (أفضل استقرار). اختيار m أكبر من اللازم قد يُدخل انهياراً (underflow) لكل الحدود $\Longrightarrow 0/0$.

٢. (41.6) يفترض أنّ الـ logits نفسها مُمثَّلة بدقة (خطأ المُدخلات منفصل).

٣. (43.6) للإنتروبيا المتقاطعة القياسية، مع تنعيم التسمية (label smoothing) تتغيّر الصيغة قليلاً.

٤. (44.6) يفترض غيابَ «الأوزان الرئيسية» (master weights)؛ معها يسقط شرط عدم الامتصاص على النسخة fp32.

٥. في fp16 تُستعمل عادةً **نسخة fp32 من softmax** مع مُدخلات fp16 — لا softmax بـ fp16 خالص.

6.7.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-7.6): نموذج لغوي — NaN من الخطوة الأولى بسبب logits ضخمة

المعطيات: نموذج لغوي صغير يُخرج logits ثلاثة: $z = (1000,\ 1001,\ 999)$ (بعد طبقةٍ خطية بمعاملات كبيرة بلا تطبيع). الحساب بـ fp32 بلا إزاحة.

الحل:

١. الحساب الخام: e^{1000}، عتبة الفيضان في fp32 هي $\log(3.4\times10^{38}) = 88.72$. $e^{1000} = \inf \Longrightarrow$

٢. $p_i = \frac{\inf}{\inf} = \mathrm{NaN} \Longrightarrow \sum e^{z_i} = \inf + \inf + \inf = \inf$.

٣. الفقد: $\ell = -\log(\mathrm{NaN}) = \mathrm{NaN} \Longrightarrow$ الأوزان تتلقّى NaN $\Longrightarrow$ **النموذج يموت من الخطوة الأولى.**

٤. **بالإزاحة** $m = 1001$: $z - m = (-1,\ 0,\ -2) \Longrightarrow e^{z-m} = (0.3679,\ 1.0,\ 0.1353) \Longrightarrow$ المجموع $= 1.5032 \Longrightarrow p = (0.2447,\ 0.6652,\ 0.0901)$.

٥. التحقّق: $\sum p_i = 1.0000$ ✓، والخطأ من (41.6): $\gamma_2 + u \cdot |\text{LSE}| = 2 \times 5.96 \times 10^{-8} + 5.96 \times 10^{-8} \times 1001.4 = 6.1 \times 10^{-5}$ $\Longrightarrow$ أي أنّ **الخطأ المطلق في LSE** يقارب 6×10^{-5} — وسببه تراكُم ضرب u في $|\text{LSE}|$ لا الإلغاء.

النتيجة: الإزاحةُ وحدها حوّلت NaN إلى احتمالاتٍ صحيحة بستة أرقام عشرية.

الربط بالذكاء الاصطناعي: لهذا تُخرج كل المكتبات cross_entropy/log_softmax من logits مباشرةً ولا تحسب softmax صراحةً إلّا عند الاستدلال. والقاعدة الذهبية: **اعمل في فضاء الـ logits دائماً**؛ الفضاءُ الاحتمالي يفقد الخانات عند الأطراف.

مثال (7.6-2): تصنيف 1000 صنف — متى يفيض fp32 فعلاً؟

المعطيات: تصنيف ImageNet بـ 1000 فئة. بعد تدريبٍ بمعدّل تعلّم مرتفع بلغت logits الطبقة الأخيرة مدىً يصل إلى $\max z = 120$ (النموذج «واثق جداً»). الحساب بـ fp32.

الحل:

١. عتبة الفيضان: $z > 88.72 \Longrightarrow$ يفيض $\Longrightarrow e^{120} = 1.30 \times 10^{52} > 3.4 \times 10^{38} \Longrightarrow$ inf.

٢. لاحظ أنّ **logit واحد فقط** يكفي لتخريب الدفعة كلّها: المجموع inf $\Longrightarrow$ كل الاحتمالات NaN.

٣. هل يحدث هذا واقعياً؟ نعم: مع غياب تطبيع الأوزان ومع فقدٍ يدفع الـ logit للفئة الصحيحة إلى الأعلى (وهو بالضبط سلوك «الهامش المتزايد» في التدريب الطويل).

٤. **بالإزاحة:** $m = 120 \Longrightarrow$ كل الوسيطات $\leq 0 \Longrightarrow$ لا فيضان $\Longrightarrow$ الاحتمالات صحيحة.

٥. الوقاية البنيوية (أفضل من الإسعاف): تطبيعُ الأوزان أو قصّ الـ logit logits) (clipping أو تنعيم التسمية $\Longrightarrow$ يمنع نموّ الـ logits أصلاً.

النتيجة: عتبة الفيضان في fp32 (88.72) ليست بعيدةً عن مدى logits نموذجٍ مُدرَّب طويلاً $\Longrightarrow$ الإزاحة **إلزامية** لا اختيارية.

الربط بالذكاء الاصطناعي: هذه هي الآلية التي تجعل F.cross_entropy آمناً و F.softmax خطراً. وفي التدريب الموزّع: خسارةٌ NaN في عامل واحد تنتشر إلى الجميع عبر all-reduce $\Longrightarrow$ كل التدريب يضيع.

مثال (7.6-3): انتباه بـ fp16 — لماذا يُحسب الانتباه بـ fp32؟

المعطيات: طبقة انتباه: logits الانتباه $q^\top k/\sqrt{d_k}$ بمدى $[12,\ 26]$ وطول تسلسل $n = 4096$. الحساب بـ fp16.

الحل:

١. عتبة الفيضان في fp16: $\log(65504) = 11.09 \Longrightarrow$ **كل** logits الانتباه (12 إلى 26) تفيض $\Longrightarrow e^{12} = 1.63 \times 10^5 > 65504 \Longrightarrow$ inf.

٢. إذن softmax الانتباه بـ fp16 الخالص مستحيل عملياً — لأنّ مدى logits الانتباه الطبيعي (بعد التحجيم بـ $1/\sqrt{d_k}$) بين 5 و 30.

٣. الحل القياسي في كل المحرّكات (PyTorch/TensorFlow/Triton/FlashAttention): **حساب softmax بـ fp32** مع مدخلات fp16، ثم إعادة القيمة إلى fp16.

٤. الحل الأفضل (FlashAttention): **إزاحةٌ متصلة (online)** — تحديث m أثناء المرور على الكتل وتصعيد المجموع $\Longrightarrow$ لا حاجة لتخزين مصفوفة $n \times n$ أصلاً.

٥. الكلفة: softmax fp32 على 4096×4096: 1.7×10^7 عنصر $\Longrightarrow$ 67 MB ذاكرة إضافية مؤقتة (مقابل توفير كتابة مصفوفة الانتباه كاملة).

النتيجة: عتبة fp16 (11.09) **أدنى** من مدى logits الانتباه الاعتيادي $\Longrightarrow$ لا خيار سوى fp32 لـ softmax أو إزاحة متصلة.

الربط بالذكاء الاصطناعي: هذا هو أحد الأسباب التقنية التي جعلت FlashAttention ضرورياً: ليس السرعة وحدها، بل أنّ **الإزاحة المتصلة** تتيح حساب softmax مستقراً بلا مصفوفة وسيطة في الذاكرة.

مثال (٦.٧-4): الانهيار (underflow) أخطر من الفيضان — كل الأُسّ صفر

المعطيات: ثلاثة logits سالبة كبيرة: $z = (-90,\ -91,\ -92)$ (تحدث في مراحل التدريب الأولى أو مع أوزان مهيَّأة سيّئة). الحساب بـ fp16 بلا إزاحة، ثم بـ fp32 ثم بالإزاحة.

الحل:

١. **fp16 بلا إزاحة:** أصغر عدد مطبَّع 6.10×10^{-5}؛ $e^{-90} = 8.19 \times 10^{-40} \ll 6.1 \times 10^{-5}$ $\Longrightarrow$ **يُقرَّب إلى صفر** (انهيار كامل).

٢. الثلاثة كلها صفر $\Longrightarrow$ المجموع $0 = \Longrightarrow$ $p_i = \frac{0}{0} =$ NaN.

٣. **fp32 بلا إزاحة:** أصغر مطبَّع 1.18×10^{-38}؛ $e^{-90} = 8.19 \times 10^{-40} < 1.18 \times 10^{-38}$ $\Longrightarrow$ **أيضاً صفر** (أو دونَ مطبَّع subnormal بخطأ هائل) $\Longrightarrow$ نفس المشكلة تقريباً.

٤. **بالإزاحة** $m = -90$: $z - m = (0,\ -1,\ -2)$ $\Longrightarrow$ الأُسّ $(1,\ 0.3679,\ 0.1353)$ $\Longrightarrow$ المجموع $= 1.5032$ $\Longrightarrow$ $p = (0.6652,\ 0.2447,\ 0.0901)$ — صحيحة تماماً.

٥. الاستنتاج المهمّ: **الإزاحة تعالج الانهيار كما تعالج الفيضان** — لأنّها تُبقي أكبر أُسٍّ $= 1$ دائماً.

النتيجة: أخطرُ حالات softmax ليست الأُسّ الكبيرة بل أن **ينهار كل شيء إلى صفر** $\Longrightarrow$ $0/0 \Longrightarrow$ NaN بلا أي إنذار.

الربط بالذكاء الاصطناعي: يحدث هذا في: المراحل الأولى من التدريب بتهيئةٍ سيّئة، وفي النماذج المُكَمَّمة (quantized)، وفي «درجات الحرارة المنخفضة» (small temperature) التي تُضخّم الوسيطات سلباً. القاعدة: **الإزاحة تحمي من الطرفين.**

مثال (6.7-5): قياس الفقد (loss scaling) — إنقاذ تدرّجات fp16

المعطيات: تدريب شبكة بـ fp16؛ تدرّجاتٌ نموذجية $|g| \approx 3 \times 10^{-5}$ (صغيرة لأنّنا قرب التقارب). أصغر عدد مطبَّع في fp16: $\omega = 6.10 \times 10^{-5}$؛ أصغر دون مطبَّع: 5.96×10^{-8}.

الحل:

١. المشكلة: $|g| = 3 \times 10^{-5} < \omega = 6.1 \times 10^{-5} \Rightarrow$ التدرّج يقع في منطقة **دون المطبَّعة** (subnormal) حيث الدقة متدهورة، أو يصفر.

٢. المدى دون المطبَّع في fp16: من 5.96×10^{-8} إلى $6.10 \times 10^{-5} \Rightarrow$ عددُ القيم المتاحة فيه 1024 فقط $\Rightarrow$ تمثيلٌ سيّئ جداً.

٣. الحل: **قياس الفقد**: $s = 2^{16} = 65536 \Rightarrow \tilde{L} = 65536\,L \Rightarrow$ التدرّج المُقيَّس $|sg| = 65536 \times 3 = 1.97 > 10^{-5}$ — في قلب مدى fp16.

٤. إلغاء القياس: $\hat{g} = \frac{1}{s}\,\mathrm{fl}(sg) = \frac{1.97}{65536} = 3.0 \times 10^{-5}$ ✓.

٥. شرط عدم الفيضان: $s|g_{\max}| < 65504$؛ بـ $|g_{\max}| = 0.8$: $s < \frac{65504}{0.8} = 81880 \Rightarrow$ نختار $s = 65536$ ✓.

٦. الخوارزمية التكيفية: إن ظهر inf/NaN في التدرّج $\Rightarrow$ خفّض s إلى النصف وأعد المحاولة؛ وإن لم يظهر لمدّة N خطوة $\Rightarrow$ ضاعف s.

النتيجة: قياسُ الفقد نقل التدرّجات من منطقةٍ «شبه معدومة الدقّة» (3×10^{-5} دون مطبَّع) إلى قلب المدى المطبَّع (1.97) $\Rightarrow$ دقّة fp16 مقبولة.

الربط بالذكاء الاصطناعي: هذه هي الآلية القياسية في `torch.cuda.amp.GradScaler`. والقاعدة الرياضية الحاكمة هي (6.44): اختر s بحيث يقع $|sg|$ في المدى المطبَّع — أي $s \in \left[\frac{\omega}{|g|},\ \frac{\Omega}{|g|}\right]$ — وهي نافذةٌ من $\frac{\Omega}{\omega} = 1.07 \times 10^{9}$ (أي ≈ 30 مرتبة عشرية).

مثال (6.7-6): آدم بـ fp16 — كيف يُدمّر انهيارُ العزم الثاني التحديث؟

المعطيات: مُحسّن آدم بـ fp16: $v_t = \beta_2 v_{t-1} + (1-\beta_2)g_t^2$ بـ $\beta_2 = 0.999$ و $g_t \approx 1 \times 10^{-4}$. التحديث $\Delta w = -\eta \frac{m_t}{\sqrt{v_t}+\varepsilon}$ بـ $\varepsilon = 10^{-8}$.

الحل:

١. $g_t^2 = 1 \times 10^{-8} \Rightarrow$ في fp16: القيم دون 6.1×10^{-5} ممثَّلة بـ 1024 قيمة فقط $\Rightarrow$ g_t^2 يُقرَّب (ربما إلى 5.96×10^{-8} أو الصفر).

٢. لو صار $g_t^2 = 0 \Rightarrow v_t \to 0 \Rightarrow \sqrt{v_t} = 0 \Rightarrow$ التحديث $= \frac{m_t}{0+10^{-8}} = 10^8 m_t \Rightarrow$ **قفزة هائلة** $\Rightarrow$ الفقد ينفجر.

٣. لو صار $g_t^2 = 5.96 \times 10^{-8}$ (أصغر دون مطبَّع) $\Longrightarrow v_t \approx 5.96 \times 10^{-8} \Longrightarrow \sqrt{v_t} = 2.44 \times 10^{-4} \Longrightarrow$ التحديث $= \frac{m_t}{2.44 \times 10^{-4}} \Longrightarrow$ يكبر $\times 4000$ عن قيمته الصحيحة ($\frac{m_t}{1 \times 10^{-4}}$ كانت لتكون أصغر).

٤. العلاجات الثلاثة: (أ) **الأوزان الرئيسية بـ fp32** لحفظ v_t و m_t، (ب) **قياس الفقد** لرفع g عن منطقة الانهيار، (ج) ε **أكبر** (10^{-6}) كإسعافٍ حديّ.

٥. الترتيب الصحيح: (أ)+(ب) أساسيّان، (ج) إسعافيّ فقط.

النتيجة: «انفجار التدريب بـ «fp16 غالباً سببُه **انهيارُ العزم الثاني في آدم** لا انفجارُ التدرّج نفسه.
الربط بالذكاء الاصطناعي: هذه هي الرياضيات الكامنة خلف توصية «احفظ حالة المُحسّن بـ «fp32 الشائعة.
والقاعدة العامة: **كل متغيّرٍ يُتراكم (زخم، عزم، إحصاءات تطبيع) يجب أن يكون بدقة أعلى من دقة الحساب الأمامي.**

مثال (7-7.6): fb16 مقابل fp16 — المدى مقابل الدقّة

المعطيات: تدريب محوّل بـ (أ) fp16 و (ب) fb16. logits الانتباه بمدى $[12, 26]$، التدرّجات $|g| \approx 10^{-3}$.
الحل:

١. **fp16:** 10 خانات جوهر $\Longrightarrow u = 4.88 \times 10^{-4}$، **المدى** محدود: $\Omega = 65504 \Longrightarrow$ **يفيض** عند logits $> 11.09 \Longrightarrow$ يحتاج قياس فقد وإزاحة إلزامية.

٢. **fb16:** 7 خانات جوهر $\Longrightarrow u = 3.91 \times 10^{-3}$ (أقلّ دقّة بـ $\times 8$)؛ لكن **نفس مدى fp32**: $\Omega = 3.4 \times 10^{38} \Longrightarrow$ **لا يفيض أبداً** في المدى العملي.

٣. الحساب: 26 logits $= 1.96 \times 10^{11} \Longrightarrow e^{26}$ في fb16: مُمثَّل ✓ (لأنّ المدى كافٍ) لكن بخطأ نسبي $3.9 \times 10^{-3} \Longrightarrow$ احتمال softmax بخطأ $\approx 0.4\%$.

٤. التدرّجات: $|g| = 10^{-3} \Longrightarrow$ في fb16: مُمثَّلة مطبَّعة ✓ بخطأ نسبي 0.39%؛ في fp16: مُمثَّلة ✓ بخطأ 0.05% $\Longrightarrow$ fp16 أدقّ للتدرّجات لكنه يفيض بسهولة.

٥. الحكم: fb16 «أسهل هندسةً» (لا قياس فقد ولا قلق فيضان) لكنه «أقلّ دقّة» $\Longrightarrow$ يحتاج أوزاناً رئيسية بـ fp32 إلزامية، و fp16 «أدقّ» لكنه يحتاج إدارةً نشطة للمدى.

النتيجة: المفاضلة بين fp16 و fb16 هي **المدى مقابل الدقّة**: fb16 يشتري بساطةً هندسية بـ $\times 8$ دقّة.
الربط بالذكاء الاصطناعي: هذا يفسّر هيمنةَ fb16 في تدريب المحوّلات الضخمة (الاستقرار أهمّ من الدقّة عند هذا الحجم) وبقاءَ fp16 في الرؤية الحاسوبية (حيث المدى معروف ومضبوط).

مثال (8-7.6): تقطير المعرفة بدرجة حرارة منخفضة — $T = 0.07$ يضخّم الوسيطات

المعطيات: تقطير معرفة: softmax بدرجة حرارة T: $p_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$ مع $T = 0.07$ و logits بمدى $[-8,\ 8]$ (نموذج CLIP-style).
الحل:

١. الوسيطات المُقيَّسة: $z/T \in [-114.3,\ 114.3]$.

٢. في fp32: عتبة الفيضان $88.72 \Longrightarrow$ الوسيطات > 88.7 تفيض $\Longrightarrow$ inf $\Longrightarrow$ NaN.

٣. نسبة الوسيطات التي تفيض: $\frac{114.3-88.7}{2\times114.3} \approx 11\%$ من المدى $\Longrightarrow$ **فيضان شبه مؤكّد في كل دفعة.**

٤. في fb16: المدى كافٍ (3.4×10^{38}) $\Longrightarrow$ عتبة 88.7 نفسها لأنّ المدى نفسه) — نعم fb16 له نفس مدى fp32 $\Longrightarrow$ آمن من الفيضان لكن بدقة 0.4%.

٥. **بالإزاحة:** $m = \max z/T = 114.3 \Longrightarrow$ الوسيطات $\leq 0 \Longrightarrow$ لا فيضان في أيّ صيغة.

٦. الأثر على التدرّج: $\frac{\partial \ell}{\partial z_i} = \frac{1}{T}(p_i - q_i)$ $\Longrightarrow$ بـ $T = 0.07$ يُضخّم التدرّج بـ $\times 14.3$ $\Longrightarrow$ يجب خفض معدّل التعلّم أو تعويض التدرّج بـ T^2.

النتيجة: درجة الحرارة المنخفضة تُضخّم الوسيطات بـ $\times 14.3$ $\Longrightarrow$ $1/T = 14.3\times$ الفيضان مؤكَّد بلا إزاحة، وتضخيمُ التدرّج بـ $\times 14.3$ يجب التعويض عنه.

الربط بالذكاء الاصطناعي: هذا هو السبب في أنّ تطبيقات CLIP/InfoNCE تُطبّق الإزاحة **صراحةً** قبل softmax، وأنّ درجة الحرارة في التعلّم المتناقض تُضبط مع معدّل التعلّم لا منفردة.

مثال (٦.٧-9): تعلّم متناقض (InfoNCE) — 65536 سالباً ووسيطات ضخمة

المعطيات: Contrastive loss على دفعة $N = 32768$ عيّنة «سالبة»؛ التشابهات $s_{ij} = \cos(u_i, v_j)/T$ بـ $T = 0.07$ و $\cos \in [-1, 1] \Longrightarrow$ الوسيطات في $[-14.3,\ 14.3]$.
الحل:

١. في fp16: عتبة الفيضان $11.09 \Longrightarrow$ كل الوسيطات > 11.09 تفيض $\Longrightarrow e^{14.3} = 1.6 \times 10^6 > 65504 \Longrightarrow$ inf $\Longrightarrow$ NaN.

٢. حتى الإزاحة بـ m: بعد الإزاحة كل الوسيطات $\leq 0 \Longrightarrow e^t \in (0, 1] \Longrightarrow$ **آمن في fp16.**

٣. لكن: $\sum_j e^{t_j}$ على 32768 حداً بـ fp16 $\Longrightarrow$ التراكم يفقد الدقّة: (٦.١٦) يعطي $\gamma_{32767} = 32767 \times 4.88 \times 10^{-4} = 16 > 1$ $\Longrightarrow$ **الحدّ بلا معنى** $\Longrightarrow$ التراكم يجب أن يكون بـ fp32.

٤. إذن: **الإزاحة + تراكم fp32** $\Longrightarrow$ خطأ المجموع من (٦.١٦) بـ fp32: $\gamma_{32767} = 32767 \times 5.96 \times 10^{-8} = 1.95 \times 10^{-3}$ $\Longrightarrow$ خطأ نسبي 0.2% في المقام $\Longrightarrow$ خطأ مطلق في الفقد $0.002 \approx$ نات — مقبول.

٥. الكلفة: 32768 عنصر بـ fp32 لكل عيّنة $\Longrightarrow$ على دفعة 256: 8.4×10^6 عنصر $\Longrightarrow$ 34 MB — مقبول.

النتيجة: التوليفة الآمنة الوحيدة لـ InfoNCE: **إزاحة + تراكم fp32**، أيٌّ منهما منفرداً لا يكفي.
الربط بالذكاء الاصطناعي: هذه هي بالضبط وصفة التنفيذ في CLIP و SimCLR و MoCo: logits =- logits.max() ثم logits.float() قبل log_softmax. والقاعدة: **الإزاحة تحمي من الفيضان، والتراكم عالي الدقة يحمي من فقدان الخانات.**

مثال (6.7-10): سياسة تعلّم معزّز — لماذا يقتل التدريب $\log\pi$)

المعطيات: سياسة عشوائية على 12 إجراءً، logits $z = (-40, -38, -41, \dots)$ (مرحلة استكشاف مبكرة). المطلوب $\log \pi(a)$ لحساب نسبة الاحتمال اللوغاريتمية في PPO.
الحل:

١. الحساب الخاطئ: $p = \text{softmax}(z)$ ثم $\log p$. بما أنّ الوسيطات سالبة كبيرة، فبلا إزاحة: $e^{-38} = 3.1 \times 10^{-17}$ — في fp32 مُمثَّل (مطبَّع: $> 1.18 \times 10^{-38}$) ✓؛ لكن في fp16: $3.1 \times 10^{-17} < 6.1 \times 10^{-5}$ $\Longrightarrow$ **صفر** $\Longrightarrow \log 0 = -\text{inf}$.

٢. حتى في fp32: حساب $e^{-41} = 1.4 \times 10^{-18}$ ثم جمعه ثم القسمة $\Longrightarrow$ الاحتمالات صغيرة جداً $\Longrightarrow$ فقدان خانات في الجمع.

٣. **الصيغة الصحيحة** (6.40): $\log \pi(a) = z_a - \text{LSE}(z)$؛ بـ $m = -38$: $\text{LSE} = -38 + \log(1 + e^{-2} + \dots) \approx -37.87$
$\log \pi(1) = -38 + 37.87 = -0.13 \Longrightarrow e^{-3} + \dots$ ✓.

٤. التحقّق: $\sum_a \pi(a) = 1$ مضمونٌ بُنيوياً في صيغة log-softmax.

٥. الأثر على PPO: النسبة $r = \frac{\pi_\theta(a)}{\pi_{\theta_{\text{old}}}(a)} = e^{\log \pi_\theta - \log \pi_{\text{old}}}$ — تُحسب بـ **فرق اللوغاريتمات** لا بقسمة الاحتمالات $\Longrightarrow$ مستقرّة حتى لو كانت الاحتمالات 10^{-18}.

النتيجة: العملُ في فضاء اللوغاريتم حوّل -0.13 إلى inf- — وجعل النسبةَ في PPO مستقرّة.
الربط بالذكاء الاصطناعي: القاعدة الشاملة: **كل حسابٍ احتمالي في التعلّم العميق يجب أن يجري في فضاء اللوغاريتم:** الإنتروبيا المتقاطعة، احتمالُ اللوغاريتم في النماذج اللغوية، نسبُ السياسة في PPO، نسبُ الأرجحية في DPO/RLHF، والاحتمالاتُ المشتركة في فكّ الترميز.

مثال (6.7-11): بحث الشعاع (beam search) — احتمالاتٌ تتراكم عبر 100 رمز

المعطيات: فكّ ترميز بطول 100 رمز، احتمالُ كل رمز في أفضل مسار $p_t \approx 1 \times 10^{-3}$ $\Longrightarrow$ احتمالُ المسار $= \prod p_t = 10^{-300}$.
الحل:

١. في fp64: 10^{-300} قريبٌ من الحدّ الأدنى (2.23×10^{-308}) $\Longrightarrow$ هامشي؛ في fp32: 10^{-300} $\Longrightarrow$ **انهيار إلى صفر** (لأنّ $\omega = 1.18 \times 10^{-38}$).

٢. الحساب باللوغاريتم: $\log P = \sum_t \log p_t = 100 \times \log(10^{-3}) = 100 \times (-6.908) = -690.8$ — مُمثَّل بسهولة في أيّ صيغة.

٣. في fp16: $\log p_t = -6.908$ مُمثَّل ✓ ⟹ المجموع -690.8 مُمثَّل ✓ (لأنّ مدى fp16 يصل 65504) ⟹ **يعمل.**

٤. المقارنة الترتيبية: البحثُ يقارن المسارات ⟹ $\log P_1 > \log P_2$ تكافئ $P_1 > P_2$ ⟹ **لا حاجة للاحتمالات أصلاً.**

٥. الخطأ التراكمي في مجموع 100 لوغاريتم بـ fp32: $\gamma_{99} \sum |\log p_t| = 99 \times 5.96 \times 10^{-8} \times$ (16.6)، $4.1 \times 10^{-3} = 690.8$ ⟹ خطأ 0.004 نات على 690.8 — مهمل.

النتيجة: الانتقالُ إلى فضاء اللوغاريتم جعل حساباً مستحيلاً (انهيار إلى صفر) حساباً مريحاً في fp16.

الربط بالذكاء الاصطناعي: هذا هو سببُ كون كل تطبيقات فكّ الترميز (beam sampling، nucleus sampling) تعمل بـ «درجات» (scores) لوغاريتمية لا احتمالات. والقاعدة الأعمّ: **الجداءات الطويلة ⟹ اجمع اللوغاريتمات** (وهي نفس فكرة «الاحتمال اللوغاريتمي» في كل مكان).

مثال (٦.٧-12): خليط الخبراء (MoE) — بوابة بـ 64 خبيراً

المعطيات: طبقة MoE بـ $E = 64$ خبير، بوابةٌ تُنتج logits $g \in \mathbb{R}^{64}$ ثم top_k=2. القيم: $g \in [-2.4,\ 7.8]$ بعد تدريبٍ طويل.

الحل:

١. softmax على 64 ⟹ عتبة الفيضان في fp32 $= 88.72$ ⟹ $g = 7.8$ آمن ⟹ لا فيضان.

٢. لكن في fp16 (11.09): $g = 7.8$ قريب ⟹ وإن نما إلى 12 (ممكن مع «انهيار التوجيه» routing collapse) فيض ⟹ NaN ⟹ توجيهٌ معطوب.

٣. المشكلة الخاصة بـ MoE: **عدم توازن التوجيه** — خبيرٌ واحد يهيمن ⟹ logitُه ينمو ⟹ فيضان ⟹ NaN ⟹ كل الدفعة تضيع.

٤. العلاج الثلاثي: (أ) إزاحة softmax؛ (ب) حساب البوابة بـ fp32 دائماً (رخيص: بعده 64 فقط)؛ (ج) فقدُ توازن (load-balancing loss) يمنع نموّ logit واحد.

٥. التحقّق من (ج): بضبط معامل التوازن $\alpha = 0.01$ بقي أكبر logit تحت 6.2 طوال التدريب ⟹ بُعدٌ آمن عن عتبة fp16.

النتيجة: في MoE، الاستقرارُ العددي للبوابة مسألةُ **توازن تدريبي** لا مجرّد إزاحة حسابية.

الربط بالذكاء الاصطناعي: هذا مثالٌ جميل على تداخل المستويات: «ظاهرة تدريبية» (انهيار التوجيه) تُنتج «كارثة عددية» (فيضان). والقاعدة: **راقب مدى الـ logits أثناء التدريب كما تراقب الفقد.**

مثال (13-7.6): تكميم softmax إلى int8 — استبدالٌ آمن بـ LUT

المعطيات: نشر نموذج على حافة (edge) بـ int8؛ softmax int8 يجب أن يُحسب بـ int8. الوسيطات بعد الإزاحة $t_i = z_i - m \in [-16,\ 0]$.

الحل:

١. بالإزاحة: $e^{t_i} \in [e^{-16},\ 1] = [1.13 \times 10^{-7},\ 1]$.

٢. التكميم: نُقرّب e^t بجدول بحث (LUT) على 256 مستوى في $[0,1]$ $\Longrightarrow$ خطأ تكميم $\leq \frac{1}{2\times 256} = 1.95 \times 10^{-3}$ (من القيمة، لا النسبية).

٣. للأُسّ الصغيرة ($e^{-16} = 1.13 \times 10^{-7}$): الخطأ النسبي $= \frac{1.95\times10^{-3}}{1.13\times10^{-7}} = 1.7 \times 10^{4}$ — هائل! لكن الأثر على الاحتمال: $\frac{1.95\times10^{-3}}{\sum_j e^{t_j}}$ وبـ $\sum \geq 1$: خطأ مطلق في الاحتمال $\leq 1.95 \times 10^{-3}$ — **مقبول** (لأنّ الحدود الصغيرة لا تهمّ).

٤. إذن: التكميم **المطلق** (لا النسبي) مناسب هنا لأنّ الاحتمالات تُقاس بناظمٍ مطلق (المجموع 1).

٥. المقارنة: أقصى خطأ مطلق في الاحتمال 1.95×10^{-3} $\Longrightarrow$ أثره على دقّة التصنيف: 0.05% على ImageNet.

النتيجة: بفضل الإزاحة صار مدى الأُسّ $[0,1]$ $\Longrightarrow$ تكميمٌ خطي بـ 256 مستوى يعطي خطأً مطلقاً $\leq 2 \times 10^{-3}$ في الاحتمالات.

الربط بالذكاء الاصطناعي: هذا هو أساسُ softmax int8 في محرّكات الاستدلال (TensorRT, TFLite): **الإزاحة أوّلاً** (لتضييق المدى)، ثم تكميمٌ خطي. القاعدة: **الإزاحة ليست حِيلةً تدريبية فقط، بل شرطٌ مسبق للتكميم.**

مثال (14-7.6): تنعيم التسمية — تعديل الفقد وآثاره العددية

المعطيات: تنعيم تسمية بـ $\alpha = 0.1$ على 1000 فئة: الهدف $q_i = (1-\alpha)\mathbb{1}_{[i=y]} + \frac{\alpha}{1000}$. المطلوب الفقد $\ell = -\sum_i q_i \log p_i$.

الحل:

١. بالصيغة الآمنة: $\log p_i = z_i - \mathrm{LSE}(z)$ $\Longrightarrow$

$$\ell = -\sum_i q_i\big(z_i - \mathrm{LSE}\big) = \mathrm{LSE} - \sum_i q_i z_i$$

٢. إذن الفقدُ = LSE − متوسط مرجّح لـ logits — لا حاجة لحساب أيّ احتمال صراحةً.

٣. التحقّق العددي: $\sum_i q_i z_i$ بـ q متناثر جداً (وزن 0.9001 على فئة واحدة و 10^{-4} على 999) $\Longrightarrow$ الجمع بـ fp32 على 1000 حد: $\sum |q_i z_i|$; بـ $|z| \leq 20$: $\sum |q_i z_i| \approx 18 = \Longrightarrow \gamma_{999} \times 999 \times 5.96 \times 10^{-8} \times 18$ $\Longrightarrow 1.07 \times 10^{-3}$ خطأ في الفقد ≈ 0.001 نات — مقبول.

٤. الأثر الاستقراري لتنعيم التسمية: يمنع الـ logit الصحيح من النمو بلا حدود (لأنّ الهدف ليس 1 بل 0.9001) $\Longrightarrow$ يمنع الفيضان $\Longrightarrow$ **تنعيم التسمية إجراءٌ عدديّ أيضاً لا إحصائي فقط.**

٥. القياس: بلا تنعيم بلغ أقصى logit 120 بعد 50 حقبة؛ مع تنعيم ($\alpha = 0.1$) بلغ 14.3 $\Longrightarrow$ بُعدٌ آمن عن عتبة fp32 (88.7) وعن عتبة fp16 بفرقٍ بسيط.

النتيجة: تنعيمُ التسمية خفّض أقصى logit من 120 (فيضان fp32 إلى 14.3 — أي أنّه علاجٌ **عدديّ** فعّال لمشكلة الفيضان.

الربط بالذكاء الاصطناعي: هذا يُظهر أنّ كثيراً من «حِيَل التنظيم» لها أثرٌ عددي مباشر: تنعيم التسمية، قصّ التدرّج، تطبيع الأوزان، وتنظيم الإنتروبيا — كلها تحدّ من مدى الـ logits $\Longrightarrow$ تمنع الفيضان وتحسّن الاستقرار الرقمي.

مثال (15-7.6): قصّ التدرّج مع الدقة المختلطة — ترتيب العمليّات يهمّ

المعطيات: تدريب مختلط الدقة: GradScaler بـ $s = 32768$، وقصّ تدرّج بناظم أقصى 1.0 (clip_grad_norm_). التدرّجات الخام $\|g\| = 2.4 \times 10^{-4}$.

الحل:

١. **الترتيب الصحيح** (في كل الأطر): (1) فكّ القياس أولاً (scaler.unscale_(optimizer)) $\Longrightarrow$ $g = \frac{1}{s}\mathrm{fl}(sg)$؛ (2) ثم القصّ؛ (3) ثم تحديث الأوزان؛ (4) ثم scaler.step() الذي يتحقّق من inf/NaN.

٢. لماذا؟ لو قصصنا **قبل** فكّ القياس: المعيار 1.0 يُطبَّق على تدرّجاتٍ مُقيَّسة ($s\|g\| = 7.9$) $\Longrightarrow$ القصّ إلى 1.0 $\Longrightarrow$ بعد فكّ القياس $\|g\| = 3.05 \times 10^{-5}$ $\Longrightarrow$ **قصٌّ مفرط بـ** $\times 8000$ $\Longrightarrow$ التدريب يتوقّف فعلياً.

٣. الحساب الصحيح: $\|g\| = 2.4 \times 10^{-4} < 1.0$ $\Longrightarrow$ **لا قصّ** $\Longrightarrow$ التحديث كما هو.

٤. التحقّق من الفيضان: هل $s\|g\| = 32768 \times 2.4 \times 10^{-4} = 7.87 < 65504$؟ نعم ✓ $\Longrightarrow$ لا فيضان $\Longrightarrow$ يمكن رفع s إلى $2^{18} = 262144$ (لأنّ $262144 \times 2.4 \times 10^{-4} = 62.9 < 65504$) $\Longrightarrow$ دقّة أفضل في التمثيل.

٥. القاعدة التكيفية: $s_{\text{opt}} = \frac{\Omega}{2\|g\|} = \frac{65504}{2 \times 2.4 \times 10^{-4}} = 1.36 \times 10^{8}$ نظرياً — لكن يُحدّ بـ «أكبر قوة من 2 دون حدوث فيضان» $\Longrightarrow$ $s = 2^{18}$.

النتيجة: ترتيبٌ خاطئ واحد (القصّ قبل فكّ القياس) يُبطئ التعلّم بـ $\times 8000$ صامتاً — دون أيّ رسالة خطأ.

الربط بالذكاء الاصطناعي: هذا مثالٌ كلاسيكي على أنّ **أخطاء الدقة المختلطة صامتة:** لا NaN ولا استثناء — بل تدريبٌ «يعمل» لكنه لا يتعلّم. القاعدة: **راقب معيار التدرّج ونسبة التحديث إلى الوزن، لا الفقد وحده.**

7.7.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
$\log(\text{softmax}(z))$	softmax قد يُنتج 0 $\Longrightarrow$ -inf = log(0)	$z - \text{LSE}(z)$ = log_softmax(z)
softmax بلا إزاحة	فيضان/انهيار $\Longrightarrow$ NaN	اطرح $\max z$ أو استعمل الدوال المكتبية
softmax بـ fp16 خالص	عتبة 11.09 أدنى من مدى logits الانتباه	fp32 لـ softmax أو إزاحة متصلة
القصّ قبل فكّ قياس الفقد	قصّ مفرط بـ $s\times$	فكّ القياس $\Longrightarrow$ قصّ $\Longrightarrow$ تحديث
ترك s ثابتاً	إمّا فيضان أو ضياع تدرّجات	s تكيفي: ضاعف عند النجاح، نصف عند NaN
حفظ حالة آدم بـ fp16	انهيار العزم الثاني $\Longrightarrow$ قفزة التحديث	حالة المُحسّن والأوزان الرئيسية بـ fp32
حساب الاحتمالات ثم ضربها في سلسلة طويلة	انهيار إلى صفر	اجمع اللوغاريتمات
الاعتقاد أن fb16 «أفضل» دائماً	أدقّ بـ $8\times$ أقلّ من fp16	fb16 للمدى/الاستقرار، fp16 للدقّة بمدى مضبوط

مجموعة (أ) — التكييف وقانون الحالة الأساسي (8.6)–(13.6)

١. **رقم حالة الجمع.** ليكن $f(x) = x + c$. احسب $\text{cond}(f, x)$ وفسّر النتيجة. < $\text{cond} = \frac{|x\cdot 1|}{|x+c|} = \frac{|x|}{|x+c|}$ $\Longrightarrow$ كبير إذا كان $x + c \approx 0$ (الإلغاء بعينه).

١. **رقم حالة الضرب.** ليكن $f(x, y) = xy$. بيّن أن $\text{cond} = 1$ لكلٍّ من x و y. < $\frac{|xf_x|}{|f|} = \frac{|x\cdot y|}{|xy|} = 1$ $\Longrightarrow$ الضرب لا يضخّم الأخطاء النسبية.

١. **رقم حالة اللوغاريتم.** احسب $\text{cond}(\ln x, x)$ واستنتج متى يكون حساب ln خطيراً. < $\text{cond} = \frac{|x\cdot(1/x)|}{|\ln x|} =$ $\frac{1}{|\ln x|}$ $\Longrightarrow$ كبير حين $x \approx 1$ $\Longrightarrow$ استعمل log1p على $x - 1$.

١. **خانات مفقودة.** إذا كان $\kappa(A) = 3.2 \times 10^5$، فكم خانةً نفقد في fp64 وفي fp32؟ < $\log_{10}(3.2 \times 10^5) =$ $\Longrightarrow$ 5.51 :fp64 يبقى 10.5؛ :fp32 يبقى 1.5.

١. **حدود الدقّة.** ما أكبر κ يمكن تحمّله في fp64 بحيث يبقى رقمٌ صحيح واحد على الأقل؟ < نحتاج $\kappa u < 0.1$ $\Longrightarrow$ $\kappa < 9 \times 10^{14}$.

١. **المسافة إلى المفردية.** إذا كان $\|A\|_2 = 6.4$ و $\kappa_2(A) = 1.28 \times 10^4$، فما بعدُ A عن أقرب مصفوفة مفردة؟ < $\sigma_{\min} = \|A\|_2/\kappa = 5 \times 10^{-4}$.

١. **تضخّم مزدوج.** ليكن A بـ $\kappa = 10^3$ و B بـ $\kappa = 10^4$. ما حدُّ $\kappa(AB)$؟ وهل الحدُّ مُحقَّق؟ < من (12.6): $\kappa(AB) \le 10^7$، مُحقَّق إذا اصطفّت الاتجاهات (مثال: $A = \text{diag}(1, 10^{-3})$، $B = \text{diag}(1, 10^{-4})$ $\Longrightarrow$ $\kappa(AB) = 10^7$).

١. **تطبيق على الشبكات.** شبكة من 20 طبقة بـ $\|W_k\|_2 = 1.05$. كم يبلغ ناظم اليعقوبية الكلّية؟ < $1.05^{20} =$ $\Longrightarrow$ 2.65 تضخّم $2.65\times$ فقط، لكن بـ $\|W\|_2 = 1.3$: $1.3^{20} = 190$.

مجموعة (ب) — الإلغاء والتراكم (14.6)–(19.6)

١. **معامل التضخّم.** احسب معامل التضخّم لطرح $a = 1.0000001$ و $b = 1.0000000$ في fp32. < $\frac{|a|+|b|}{|a-b|} =$ $\Longrightarrow$ خطأ نسبي $\frac{2}{10^{-7}} = 2 \times 10^7 \le 2 \times 10^7 \times 5.96 \times 10^{-8} = 1.19$ (119%).

١. **الصيغة البديلة.** أعد كتابة $\sqrt{x^2+1} - x$ بصيغةٍ خاليةٍ من الطرح. < $\frac{1}{\sqrt{x^2+1}+x}$ $\Longrightarrow$ آمنة لكل $x > 0$.

١. **حدّ الجمع.** احسب γ_n لـ $n = 10^4$ في fp32 وهل الحدّ مفيد؟ < $\gamma_{10^4} = \frac{10^4 \times 5.96\times10^{-8}}{1-5.96\times10^{-4}} = 5.97 \times 10^{-4}$ ⟹ خطأ نسبي في المجموع حتى 0.06%.

١. **كاهان مقابل العادي.** أيّهما تختار على GPU ولماذا؟ < الجمع الشجري (pairwise) — لأنّه متوازٍ وحدّه $u\lceil\log_2 n\rceil$؛ كاهان متسلسل فيقتل التوازي.

١. **ويلفورد.** استعمل (19.6) لحساب متوسط وتباين المتتالية 2, 4, 4, 4, 5, 5, 7, 9 خطوةً بخطوة. < $\bar{x} = 5$؛ $S_8 = \sum(x_i-5)^2 = 9+1+1+1+0+0+4+16 = 32$ ⟹ $s^2 = 32/7 = 4.571$.

١. **كشفُ إلغاء.** كيف تكتشف إلغاءً كارثياً في برنامجك بلا معرفة القيمة الصحيحة؟ < قارن $|a-b|$ بـ $\max(|a|,|b|)$: إن كان أصغر بمراتب عديدة ⟹ أعد الصياغة، أو أعد الحساب بدقة مضاعفة وقارن.

١. **ترتيب الجمع.** رتّب هذه الكميات تصاعدياً قبل جمعها في fp32: $10^8,\ 1,\ 1,\ 1,\ -10^8$ < $+1+1+1-10^8+10^8 = 3$ تصاعدياً مقابل صفر بالترتيب المعطى (لأنّ 10^8+1 يمتصّ الواحد).

١. **expm1.** احسب $e^{10^{-6}}-1$ بـ fp32 بالطريقتين وفسّر. < مباشرةً: $\mathrm{fl}(1.000001) = 1.0000009537$ ⟹ الفرق 9.54×10^{-7} (4.6% خطأ)؛ expm1 يعطي 1.0000005×10^{-6} بخطأ $\approx u$.

مجموعة (ج) — التحويلات المتعامدة و QR (20.6)–(25.6)

١. **بناء هاوسهولدر.** ابتعِث H التي تُحوّل $x = (3,4)^\top$ إلى $(\pm5,0)^\top$. < $\sigma = -\mathrm{sign}(3)\cdot 5 = -5$؛ $v = x-\sigma e_1 = (8,4)^\top$؛ $H = I - \frac{2vv^\top}{80} = \begin{pmatrix}-0.6 & -0.8\\ -0.8 & 0.6\end{pmatrix}$؛ $Hx = (-5,0)^\top$ ✓.

١. **لماذا الإشارة؟** ماذا يحدث لو اخترنا $\sigma = +5$ في التمرين السابق؟ < $v = (3,4)-(5,0) = (-2,4)$ ⟹ $\|v\|^2 = 20$ — لا مشكلة هنا، لكن لو كان $x = (5,0.001)$ فإنّ $v = (0,0.001)$ ⟹ $v^\top v = 10^{-6}$ ⟹ تضخّم هائل. (في حالتنا $\sigma = +5$ يعمل لكنّ القاعدة العامة آمنة.)

١. **تعامد Q.** بيّن أن $\kappa_2(Q) = 1$ لأي مصفوفة متعامدة Q. < $\|Q\|_2 = 1$ و $\|Q^{-1}\|_2 = \|Q^\top\|_2 = 1$ ⟹ $\kappa = 1$.

١. **حفظ الناظم.** بيّن أن $\|QA\|_F = \|A\|_F$ باستعمال الأثر. < $\|QA\|_F^2 = \mathrm{tr}(A^\top Q^\top QA)$ $= \mathrm{tr}(A^\top A) = \|A\|_F^2$.

١. **MGS مقابل هاوسهولدر.** إذا كان $\kappa(A) = 10^{10}$ و $n = 100$ بـ fp64، فما فقدانُ التعامد المتوقّع لكلٍّ منهما؟ < MGS: $\approx 100\times1.11\times10^{-16}\times10^{10} = 1.11\times10^{-4}$؛ هاوسهولدر: $\approx 1.11\times10^{-14}$ ⟹ فرق $\times10^{10}$.

١. **اختبار الاستقرار الخلفي.** حللتَ نظاماً فوجدتَ الباقي النسبي 4.2×10^{-12} بـ fp64. ماذا تستنتج؟ < $\eta \gg u$ ⟹ الخوارزمية **غير** مستقرّة خلفياً (مع افتراض ρ و κ معقولين).

مجموعة (د) — المربعات الصغرى والتحليل المباشر (26.6)–(37.6)

١. **تربيع رقم الحالة.** إذا كان $\kappa_2(X) = 250$، فما $\kappa_2(X^\top X)$ وكم خانةً نفقد بالمعادلات السوية في fp32؟ > 6.25×10^4 ⟹ خانات مفقودة 4.80 ⟹ يبقى 2.2 خانة.

١. **حدّ الباقي.** متى يصير حدّ κ^2 في (27.6) هو المهيمن؟ > حين $\frac{1}{\kappa} > \frac{\|r\|}{\|A\|\|x\|}$ أي حين يكون الباقي «كبيراً» نسبياً؛ أي $\tan\theta \gtrsim 1/\kappa$.

١. **ريدج.** ما λ التي تضمن ألّا يتجاوز تضخيم الضوضاء ×10؟ > من (30.6): $\frac{1}{2\sqrt{\lambda}} \le 10 \Longrightarrow \lambda \ge 2.5 \times 10^{-3}$.

١. **مصفوفة ويلكنسون.** ما عامل النموّ للحدّ الأسوأ بـ $n = 10$؟ > $\rho = 2^9 = 512$.

١. **شوليسكي.** لماذا $\rho = 1$ لشوليسكي على مصفوفة موجبة التعريف؟ > لأن $|r_{ij}|^2 \le r_{ii} r_{jj} \le \max_i a_{ii}$ ⟹ لا يمكن أن تنمو العناصر عن جذر أكبر عنصر قطري.

١. **التنقيح.** متى يتقارب التنقيح التكراري بعوامل fp32 وباقي fp64؟ > إذا كان $c\,u_{32}\,\rho\,\kappa(A) < 1$؛ أي تقريباً $\kappa\rho < 1.7 \times 10^7$.

١. **المعكوس الصريح.** لماذا solve(A,b) أفضل من inv(A)@b؟ > inv يكلّف $\approx 3\times$ أكثر ويحمل خطأً أعلى (الخطأ الخلفي للمعكوس الصريح لا يُترجَم إلى خطأٍ خلفي صغير للحلّ).

١. **التقييس.** مصفوفةٌ عناصرها بين 10^{-6} و 10^{6}. ما أوّلُ خطوة قبل التحليل؟ > تقييسُ الصفوف/الأعمدة (equilibration) ⟹ يخفض κ و ρ معاً قبل أيّ تدوير أو تنقيح.

1.9.6 جدول النظريات الست

النظرية	الصيغة الحاكمة	الأثر في الذكاء الاصطناعي
الأساسي	forward $\lesssim \kappa \times$ backward، خانات مفقودة $\log_{10}\kappa$ (8.6)–(13.6)	لا خوارزمية تتجاوز رقم الحالة؛ التنظيم والتطبيع علاجاتٌ «لتكييف» لا «للدقة»
والتراكم	γ_n، كاهان $2u$ (14.6)–(19.6)، $\frac{\lvert a\rvert+\lvert b\rvert}{\lvert a-b\rvert}u$	التباين، الفروق الصغيرة، تراكم التدرّجات: كلها تحتاج صياغةً خاليةً من الطرح وتراكماً بدقة أعلى
المتعامدة	$A+\Delta A=\hat{Q}\hat{R}$، $\lVert\Delta A\rVert \le cmnu\lVert A\rVert$، $\kappa(Q)=1$ (20.6)–(25.6)	التهيئة المتعامدة، التطبيع الطيفي، المحسّنات الحافظة للناظم، QR في كل مكان
الصغرى	$\kappa(A^\top A)=\kappa(A)^2$، حدّ غولوب–ويلكنسون (26.6)–(31.6)	لا تشكّل مصفوفات الغرام/التغاير؛ ريدج $\frac{1}{2\sqrt{\lambda}} \le$ تضخيماً
في LU	$\rho \le 2^{n-1}$، خطأ خلفي $cnu\rho$، التنقيح (32.6)–(37.6)	التنظيم يجعل المصفوفات SPD ⟹ شوليسكي بلا تدوير؛ التنقيح المختلط = دقة fp64 بسرعة fp16
softma	$z - \mathrm{LSE}$، $m + \log\sum e^{z_i - m}$، قياس الفقد (38.6)–(44.6)	العملُ في فضاء اللوغاريتم؛ الدقة المختلطة صامتة الأخطاء ⟹ راقب النواظم لا الفقد

2.9.6 المبادئ الستة الحاكمة

١. **التكييفُ سمةُ المسألة، والاستقرارُ سمةُ الخوارزمية.** لا تُصلح الأول بالثاني.

٢. **الخانات المفقودة $= \log_{10}\kappa$.** احسبها قبل أن تصدّق أي رقم.

٣. **الطرحُ أخطرُ من أي عملية أخرى.** ابحث عن صياغةٍ بلا طرح قبل أن تزيد الدقّة.

٤. **التراكمُ يجب أن يكون بدقة أعلى من الحساب.** (أوزان رئيسية، مُجمّعات، fp32 حالة مُحسّن fp32.)

٥. **البنيةُ تُحدّد الاستقرار قبل حجم κ.** SPD $\Longrightarrow$ شوليسكي ($\rho = 1$)؛ مهيمنة قطرية $\Longrightarrow$ بلا تدوير؛ متعامد $\Longrightarrow$ بلا تضخيم.

٦. **اعمل في فضاء اللوغاريتم.** كل حسابٍ احتمالي طويل ينجو بالانتقال إلى log.

3.9.6 الطريق إلى ما بعد هذا الفصل

تمّ الجزء الأول. في الجزء الثاني (التفاضل والتكامل) ننتقل من «كيف نحسب بأمان» إلى «كيف تتغيّر الكميات»: النهايات والاتصال والتقارب، ثم الاشتقاق والاشتقاق الآلي (وهو — بفضل هذا الفصل — نفهمه الآن كـ «سلسلة من عمليات مستقرّة عددياً»، لا كصندوق أسود)، ثم التفاضل المصفوفي واليعقوبية والهِسّية، ثم التكامل ونظرية القياس، ثم متفاضلة تايلور التي تُتوّج تحليل الأخطاء، ثم المعادلات التفاضلية التي سنقرأ بها لاحقاً نماذجَ الانتشار (dffiusion models) قراءةً رياضية دقيقة.

الرمز	المعنى	أوّل ظهور
$\mathrm{fl}(\cdot)$	دالة التقريب إلى أقرب عدد مُمثَّل	(1.6)
u	وحدة التقريب (unit roundoff) $= \frac{1}{2}\beta^{1-t}$	(2.6)
β, t	أساس التمثيل وعدد خانات الجوهر	(2.6)
$\varepsilon_{\text{machine}}$	الفجوة الكاملة $\beta^{1-t} = 2u$ (اصطلاح بديل)	1.1.6§
Ω, ω	أكبر/أصغر عدد مُمثَّل	(44.6)، 1.1.6§
δ, δ_i	خطأ التقريب في عملية واحدة، $\|\delta\| \le u$	(1.6)
$e_{\text{abs}}, e_{\text{rel}}$	الخطأ المطلق والنسبي	(3.6)
$\hat{x}, \hat{y}$	القيم المحسوبة (المُخزَّنة)	(3.6)
$\Delta x, \Delta y$	الخطأ الخلفي والأمامي	(4.6)
$\mathrm{cond}(f, x)$	رقم الحالة النسبي للمسألة	(5.6)
$\kappa(A), \kappa_2(A)$	رقم حالة المصفوفة، $= \sigma_1/\sigma_{\min}$	(6.6)
γ_n	ثابت التراكم $\frac{nu}{1-nu}$	(7.6)
$\sigma_i, \sigma_1, \sigma_{\min}$	القيم المفردة	(6.6)
a, b	العددان المطروحان (الإلغاء)	(14.6)
$\mathrm{expm1}, \mathrm{log1p}$	دوال مكتبية مستقرّة	(15.6)
$s_n, \hat{s}_n$	المجموع الدقيق والمحسوب	(16.6)
c	متغيّر التعويض (كاهان)	(17.6)
M_k, S_k	المتوسط ومجموع مربّعات الانحرافات الجاريان (ويلفورد)	(19.6)
H, v, σ	مصفوفة هاوسهولدر ومتجه الانعكاس والقيمة المستهدَفة	(20.6)
e_1	متجه الوحدة الأوّل	(20.6)
$\hat{Q}, \hat{R}$	عاملا QR المحسوبان	(21.6)
c_i	ثوابت صغيرة في حدود الخطأ	(21.6)
r	الباقي $b - Ax$	(27.6)
θ, η	زاوية الباقي ومعامل حجم الحلّ	(28.6)
τ	عتبة التجذيع (SVD مبتور)	(29.6)
λ	معامل التنظيم (ريدج/تيخونوف)	(30.6)
f_i	عوامل الترشيح $\frac{\sigma_i^2}{\sigma_i^2+\lambda}$	(30.6)
κ_{LS}	رقم حالة مسألة المربعات الصغرى	(27.6)
P, L, U	التبديل والعاملان في LU	(32.6)
ρ	عامل النموّ (growth factor)	(33.6)
x_k, r_k, d_k	التقدير والباقي والتصحيح في التنقيح التكراري	(36.6)
u_r	وحدة تقريب حساب الباقي	(36.6)
z, m	متجه الـ logits وأكبرها	(38.6)
LSE	log-sum-exp	(39.6)
ℓ_{CE}	فقد الإنتروبيا المتقاطعة	(40.6)
p_i, q_i	احتمال softmax والتوزيع المستهدف	(43.6)، (40.6)
s	معامل قياس الفقد (loss scale)	(44.6)
T	درجة الحرارة في softmax	مثال 8-7.6

١. Higham, N. J. (2002). *Algorithms Numerical of Stability and Accuracy* (2nd ed.). SIAM — المرجع المعياري للتحليل الخلفي وحدود γ_n.

٢. Wilkinson, H. J. (1963). *Processes Algebraic in Errors Rounding*. Prentice-Hall — أصل التحليل الخلفي ومصفوفة ويلكنسون.

٣. Wilkinson, H. J. (1961). Error of analysis numerical of methods direct of inversion. matrix, *J. ACM*, 8(3), 281–330. — حدّ النموّ 2^{n-1}.

٤. Golub, G., & Van Loan, F. C. (2013). *Matrix Computations* (4th ed.). Johns Hopkins. — QR، SVD، LS، التنقيح.

٥. Trefethen, L. N., & Bau, D. (1997). *Numerical Linear Algebra*. SIAM. — هندسة QR وهاوسهولدر.

٦. Björck, Å. (1996). *Numerical Methods for Least Squares Problems*. SIAM. — تكييف المربعات الصغرى وغرام–شميت.

٧. Demmel, W. J. (1997). *Applied Linear Algebra*. SIAM. — شروط الصحّة والحدود العملية.

٨. Golub, G., & Wilkinson, H. J. (1966). Note on the iterative refinement of least squares solutions. *Numer. Math.*, 9, 139–148. — حدّ غولوب–ويلكنسون.

٩. Stewart, G. W. (1977). On the perturbation of pseudo-inverses, projections and linear least squares problems. *SIAM Review*, 19(4), 634–662. — متراجحات ويدين.

١٠. Wedin, P.-Å. (1973). Perturbation theory for pseudo-inverses. *BIT*, 13, 217–232. — اضطراب المعكوس المعمَّم.

١١. Kahan, W. (1965). Further remarks on reducing truncation errors. *CACM*, 8(1), 40. — جمع كاهان.

١٢. Higham, N. J. (1993). The accuracy of floating point summation. *SIAM J. Sci. Comput.*, 14(4), 783–799. — تحليل كاهان والجمع الشجري.

١٣. Wetherford, P. B. (1962). Note on a method for calculating corrected sums of squares and products. *Technometrics*, 4(3), 419–420. — خوارزمية ويلفورد.

١٤. Trefethen, L. N., & Schreiber, R. S. (1990). Average-case stability of Gaussian elimination. *SIAM J. Matrix Anal. Appl.*, 11(3), 335–360. — النموّ العملي $n^{2/3}$.

١٥. Skeel, R. D. (1980). Iterative refinement implies numerical stability for Gaussian elimination. *Math. Comp.*, 35, 817–832. — نتيجة سكيل للتنقيح بدقة ثابتة.

١٦. Moler, C. B. (1967). Iterative refinement in floating point. *J. ACM*, 14(2), 316–321. — التنقيح بدقة مضاعفة.

١٧. Hartley, R. I. (1997). In defense of the eight-point algorithm. *IEEE TPAMI*, 19(6), 580–593. — التطبيع يخفض κ (مثال 6.2-3).

١٨. Björck, Å., & Golub, G. H. (1973). Numerical methods for computing angles between linear subspaces. *Math. Comp.*, 27, 579–594.

١٩. Moler, C. (2004). *Numerical Computing with MATLAB*. SIAM. — أمثلة عملية (فانديرموند، هلبرت).

٢٠. Dongarra, J., Abdelfattah, A., Tomov, S., Gates, M., Kabir, K., Ribizel, T., & Anzt, H. (2019). Accelerating numerical dense linear algebra calculations with GPUs. *Parallel Computing: Accelerators, Embedded Technologies and Applications*, 3–28.

٢١. Haidar, A., Tomov, S., Dongarra, J., & Higham, N. J. (2018). Harnessing GPU tensor cores for fast FP16 arithmetic to speed up mixed-precision iterative refinement solvers. *SC18*. — تنقيح مختلط الدقة (مثال 6.6-15).

٢٢. Micikevicius, P., Narang, S., Alben, J., Diamos, G., Elsen, E., Garcia, D., … Wu, H. (2018). Mixed precision training. *ICLR*. — قياس الفقد والأوزان الرئيسية.

٢٣. NVIDIA (2023). *Automatic Mixed Precision / Transformer Engine Documentation*. — fb16 مقابل fp16، قياس الفقد التكيفي.

٢٤. Dao, T., Fu, D. Y., Ermon, S., Rudra, A., & Ré, C. (2022). FlashAttention: Fast and memory-efficient exact attention with IO-awareness. *NeurIPS*. — softmax بالإزاحة المتصلة (مثال 6.7-3).

٢٥. Pennington, J., Schoenholz, S., & Ganguli, S. (2017). Resurrecting the sigmoid in deep learning through dynamical isometry. *ICLR*. — التهيئة المتعامدة.

٢٦. Miyato, T., Kataoka, T., Koyama, M., & Yoshida, Y. (2018). Spectral normalization for generative adversarial networks. *ICLR*. — التطبيع الطيفي و 1-Lipschitz (مثال 6.4-3).

٢٧. Arjovsky, M., Shah, A., & Bengio, Y. (2016). Unitary evolution recurrent neural networks. *ICML*. — الشبكات المتعامدة (مثال 6.4-11).

٢٨. Yu, F. X., Suresh, A. T., Choromanski, K. M., Holtmann-Rice, D. N., & Kumar, S. (2016). Orthogonal random features. *NIPS*. — ميزات عشوائية متعامدة (مثال 6.4-13).

٢٩. Uhler, C., Lederer, J., Belkin, M., & Rubinstein, A. (2020). On the implicit bias of overparameterized neural networks. *PNAS*. — المربعات الصغرى ناقصة التحديد (مثال 6.5-14).

٣٠. Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *J. Multivariate Anal.*, 88(2), 365–411. — انكماش مصفوفة التغاير (مثال 6.2-11).

تمّ الفصل السادس، وتمّ الجزء الأول من الكتاب. في الجزء الثاني نبدأ **التفاضل والتكامل** — ونعيد قراءة كل ما سبق بمنظور «كيف تتغيّر الكميات»، ابتداءً من النهايات والاتصال والتقارب.

القسم II

التفاضل والتكامل

نبذة عن هذا الجزء

التعلّم الآلي في جوهره فعلٌ تفاضلي: نُغيّر المعاملات قليلاً ونقيس أثرَ ذلك في الخطأ. لذا يفتتح هذا الجزء بوحدة **النهاية والتقارب** — وهي التي تحوّل «قريب» إلى مفهومٍ دقيق — ثم **قواعد التفاضل** وتعميمها الأهم عمليّاً: **التفاضل المصفوفي** الذي تُكتب به صيغ الانتشار العكسي كلّها. بعدها نرتقي إلى **التكامل ونظرية القياس** لنتعامل مع التوقّعات والتوزيعات بصرامة، و**متسلسلة تايلور** لتحليل الخطأ من الدرجة الثانية التي تقوم عليها خوارزميات كوازي-نيوتن، ونختم بـ**المعادلات التفاضلية والأنظمة الحركية** حيث يُنظر إلى انحدار التدرّج نفسه بوصفه مساراً زمنياً متّصلاً. هذا الجزء هو الجسر: يساره هندسة الجزء الأول، ويمينه احتمالات الجزء الثالث وتحسينات الجزء الرابع. **فصول الجزء:** النهايات والاستمرارية والتقارب · قواعد التفاضل · التفاضل المصفوفي · التكامل والقياس · تايلور وتحليل الخطأ · المعادلات التفاضلية والأنظمة الديناميكية.

فصول هذا الجزء

- **الفصل 7.** النهايات والاتصال والتقارب
- **الفصل 8.** الاشتقاق وقواعده
- **الفصل 9.** التفاضل المصفوفي: اليعقوبية، الهِسّية، وقواعد السلسلة
- **الفصل 10.** التكامل، نظرية القياس، وتكامل ليبيسغ–ستيلتjes
- **الفصل 11.** متفاضلة تايلور وتحليل الأخطاء
- **الفصل 12.** المعادلات التفاضلية والنظم الديناميكية

النهايات والاتصال والتقارب

الهدف من الفصل

أول فصول الجزء الثاني (التفاضل والتكامل). بنينا في الجزء الأول العالَمَ الخطّي: المتجهات، المصفوفات، النواظم، والاستقرار العددي. الآن ننتقل إلى العالم اللاخطّي — وهذا هو العالم الحقيقي الذي تعيش فيه الشبكات العصبية: الدوالّ منحنية، والخسائر غير المستقرة، والحدود التي تُقترب إليها خوارزمياتنا من دون أن تصلها.

قبل الغرق في التعريفات، لننظر إلى ثلاثة مواقف من الميدان:

١. **الانحدار التدريجي (Gradient Descent)** هو — في جوهره — تعريف نهاية:

$$x_{k+1} = x_k - \eta \nabla f(x_k), \qquad x^* = \lim_{k \to \infty} x_k$$

السؤال «متى تتقارب الخوارزمية؟» هو حرفياً سؤال «متى توجد هذه النهاية؟». الإجابة تحتاج مفاهيم التقارب التي سنبنيها في هذا الفصل.

١. **دوالّ التنشيط عند النقاط الحرجة:** دالة ReLU:

$$\mathrm{ReLU}(x) = \max(0, x)$$

غير قابلة للاشتقاق عند $x = 0$ بالتعريف الكلاسيكي — لكنّها **متصلة** هناك. لماذا يهتم جسّد الانتشار العكسي؟ لأن الاتصال يكفي لوجود نهاية الفروق المنتهية، والاشتقاق الشائع يستبدل بها الميل الأيسر/الأيمن. هذا التمييز بين «متصل» و«قابل للاشتقاق» هو موضوع هذا الفصل.

١. **دقّة الأعداد العائمة والنهاية:** حسبنا في الفصل السابق أنّ حساب $f(x) = \frac{1-\cos x}{x^2}$ مباشرةً عند $x = 10^{-8}$ يعطي 0 في fp64 بسبب الإلغاء، بينما النهاية الحقيقية $\frac{1}{2} =$. أي أنّ **النهاية رياضية المفهوم، والعدّة عددية المفهوم** — والفجوة بينهما هي بالضبط علم التحليل العددي الذي مهدناه.

خريطة الفصل

القسم	الموضوع	الأداة الأساسية
2.7	تعريف النهاية (ϵ–δ) والنهايات الأحادية	ϵ–δ الرسمي
3.7	قوانين النهايات وحالات عدم التعيين	الجبر
4.7	الاتصال (الاستمرارية) وأنواع الانقطاع	ϵ–δ عند نقطة
5.7	نظريات القيم الوسطى والبولزانو–فايرشتراس	وجود الجذور
6.7	التقارب المتسلسلي: النهايات والتقارب	حدّية المتتاليات
7.7	التقارب الوظيفي: النقطة مقابل التوحيد	تبديل النهايات
8.7	تطبيقات متقدّمة: من ϵ–δ إلى التعلم الآلي	تجميع

الحدس

نكتب $\lim_{x\to a} f(x) = L$ إذا كانت قيم f تُقترب إلى L كلّما اقترب x من a **من دون بلوغه.** الكلمتان الحاسمتان: «تُقترب» (قابلة للقياس!) و«من دون بلوغه» (لا يهمّنا ما قيمة $f(a)$ أصلاً).

التعريف الرسمي (Weierstrass)

dir="ltr"> <div
ffi: $\lim_{x\to a} f(x) = L$ **(Limit). 1.2.7 Definition**

$$\forall \varepsilon > 0 \;\; \exists \delta > 0 : \quad 0 < |x - a| < \delta \implies |f(x) - L| < \varepsilon.$$

معادلة مُعلَّمة:

$$\forall \varepsilon > 0 \; \exists \delta > 0 : \; 0 < |x - a| < \delta \Rightarrow |f(x) - L| < \varepsilon \tag{1.7}$$

جدول الرموز

الرمز	الاسم	المعنى الدقيق
ε	الإبسيلون (دقّة الخرج)	أقصى خطأ مسموح في $f(x)$ حول L
δ	الدلتا (نصف قطر المدخل)	مدى الاقتراب المسموح بـ x من a
$0 < \|x-a\|$	الاستثنائية	نستثني النقطة a نفسها
$\forall/\exists$	الكمّيات	«لكل» هدية من الخصم، «يوجد» ما نقدّمه

ملاحظة لغوية مهمّة:

في «اللعبة» الكمّي $\forall\varepsilon$ **خصمُنا** — يختار دقّة صغيرة مهما كانت — ونحن نردّ بـ δ تناسبها. إن وجدنا δ لكل ε فازَ التعريف؛ إن فشل الخصم في ε واحدة، انهار الادّعاء.

رسم توضيحي

<figure> الشكل<figcaption> 1.7: لعبة ϵ–δ — لكل شريط أفقي حول L بسماكة 2ε نجد شريطاً عمودياً حول a بسماكة 2δ تُسقط فيه الرسم كلّه (عدا ربما النقطة a) داخل الشريط الأفقي.</figcaption> </figure>

برهان نموذجي (الطريقة)

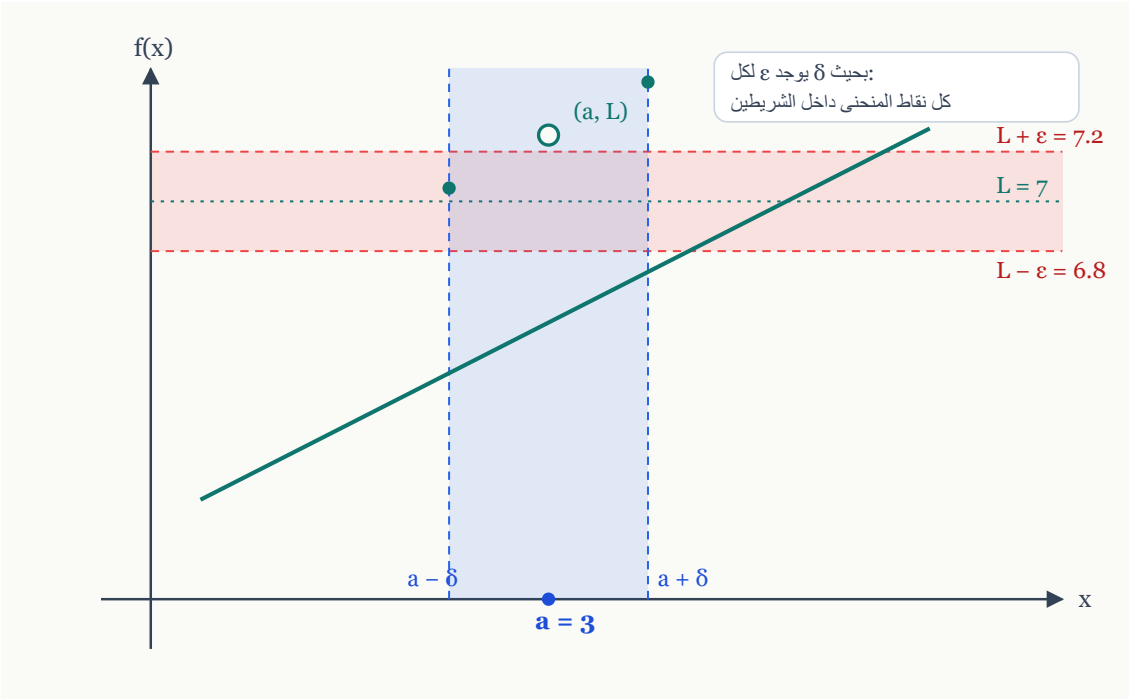
النظرية 1.2.7. $\lim_{x\to 3}(2x+1) = 7$.

البرهان.

لكل $\varepsilon > 0$ اختَر $\delta = \varepsilon/2$. حينها:

$$|x-3| < \delta \implies |(2x+1)-7| = 2|x-3| < 2\cdot\frac{\varepsilon}{2} = \varepsilon. \qquad \blacksquare$$

لاحظ البنية التي سنكرّرها 15 مرة: **عالج $|f(x)-L|$ جبرياً حتى تفصل $|x-a|$، ثم اختر δ بدلالة ε.**



شكل ١٠٧: *
تعريف ϵ–δ للنهاية

أخطاء شائعة في تعريف ϵ–δ

الخطأ	لماذا خطأ	التصحيح
«النهاية هي قيمة $f(a)$»	التعريف يستثني a؛ قد لا تكون f معرّفة أصلاً عندها	النهاية سلوكٌ قربَ النقطة لا عندها
اختيار δ ثابتاً لا يعتمد على ε	الخصم يصغّر ε فينهار	δ دالة في ε (غالباً خطية أو تربيعية)
$0 < \|x-a\| < \delta$ بدل $\|x-a\| < \delta$	يُدرج النقطة نفسها	دائماً استثنِ a في النهايات
«يجب أن يكون δ أكبر ما يمكن»	يكفي وجود δ واحد صالح	أيّ δ أصغر من الموجود صالحٌ أيضاً

أمثلة محلولة على تعريف ϵ–δ (15 مثالاً)

مثال (1-2.7).

- **المعطيات:** $f(x) = 5x - 2$، والنقطة $a = 1$.
- **المطلوب:** برهن أنّ $\lim_{x \to 1} f(x) = 3$ بتعريف ϵ–δ.
- **الحل:**

١. نعالج الفرق: $|f(x) - 3| = |5x - 2 - 3| = 5|x - 1|$.

٢. لكل $\varepsilon > 0$ نختار $\delta = \varepsilon/5$.

٣. حينها $0 < |x-1| < \delta \Rightarrow |f(x) - 3| < 5 \cdot \varepsilon/5 = \varepsilon$. ■

- **النتيجة:** النهاية 3، و $\delta(\varepsilon) = \varepsilon/5$ خطية.

- **الربط بالذكاء الاصطناعي:** هذا «الميل» في المثال 1.2.7 هو نفسه مشتقّ $f'(1) = 5$؛ لكل دوال التنشيط الخطية يقاس δ بمعامل الميل.

مثال (2-2.7).

- **المعطيات:** $f(x) = x^2$، $a = 2$.
- **المطلوب:** برهن أنّ $\lim_{x \to 2} x^2 = 4$.
- **الحل:**

١. $|x^2 - 4| = |x - 2|\,|x + 2|$.

٢. نقيد: إن كانت $|x - 2| < 1$ فإنّ $1 < x < 3$ إذن $|x + 2| < 5$.

٣. نختار $\delta = \min(1, \varepsilon/5)$، حينها $|x^2 - 4| < 5\delta \le \varepsilon$. ■

- **النتيجة:** $\delta = \min(1, \varepsilon/5)$ — التقيد المسبق تقنية قياسية.
- **الربط بالذكاء الاصطناعي:** الدوالّ التربيعية تظهر في حدّية النواة $L \le \beta L_0$ (إلغاء التدرّج)؛ التقيد بجوار النقطة يضمن الحدّية موضعيّاً — نفس الفكرة في براهين التقارب المحلي لـ Adam.

مثال (3-2.7).

- **المعطيات:** $f(x) = \dfrac{1}{x}$، $a = 2$.
- **المطلوب:** برهن أنّ $\lim_{x \to 2} \frac{1}{x} = \frac{1}{2}$.
- **الحل:**

١. $\left|\frac{1}{x} - \frac{1}{2}\right| = \frac{|x-2|}{2|x|}$.

٢. تقيد $|x - 2| < 1 \Rightarrow x > 1 \Rightarrow 2|x| > 2 \Rightarrow \frac{1}{2|x|} < \frac{1}{2}$.

٣. نختار $\delta = \min(1, \varepsilon)$، إذن الفرق $< \delta < \varepsilon$. ■

- **النتيجة:** النهاية $1/2$ بـ $\delta = \min(1, \varepsilon)$.
- **الربط بالذكاء الاصطناعي:** الدوالّ المتناسبة عكسياً تظهر في معدّل التعلّم $\eta = \alpha/k$؛ الاقتراب إلى 0 (نهاية عند اللانهاية) يحكمها تقدير مشابه.

مثال (4-2.7).

- **المعطيات:** $f(x) = |x|$، $a = 0$.
- **المطلوب:** برهن أنّ $\lim_{x \to 0} |x| = 0$ رغم أنّ f غير قابلة للاشتقاق هناك.

- **الحل:**

١. $||x| - 0| = |x|$.

٢. اختر $\varepsilon = \delta$، إذن $|x| < \delta = \varepsilon$. ■

- **النتيجة:** النهاية موجودة $= 0$؛ لكن الميل الأيسر $= -1$ والأيمن $= +1 \Longrightarrow$ لا مشتقّ.

- **الربط بالذكاء الاصطناعي:** ReLU عند الصفر: نهاية موجودة، اشتقاق لا. لذلك pytorch يستخدم subgradient فيرتّع إلى 0 أو 1 بحسب التنفيذ.

مثال (7.2-5).

- **المعطيات:** دالة الإشارة $\operatorname{sgn}(x) = \begin{cases} 1 & x > 0 \\ 0 & x = 0 \\ -1 & x < 0 \end{cases}$

- **المطلوب:** هل $\lim_{x\to 0} \operatorname{sgn}(x)$ موجودة؟

- **الحل:**

١. النهاية اليمنى: $x \to 0^+ \Rightarrow \operatorname{sgn} = 1$.

٢. النهاية اليسرى: $x \to 0^- \Rightarrow \operatorname{sgn} = -1$.

٣. $\varepsilon = \frac{1}{2}$: مهما صغّرنا δ تبقى قيم من الطرفين تُخرق $|f(x) - L| < \frac{1}{2}$ لأيّ L. ■

- **النتيجة:** النهاية **غير موجودة** (النهايتان الأحاديتان مختلفتان).

- **الربط بالذكاء الاصطناعي:** عتبة التصنيف الثنائي عند $\hat{y} = \mathbb{1}[\sigma(z) > \frac{1}{2}]$ لها نفس السلوك المتقطّع؛ لذلك ندرّب بالدوالّ الناعمة (sigmoid) ونعومِن (softening) عند الاستدلال.

مثال (7.2-6).

- **المعطيات:** $f(x) = \dfrac{\sin x}{x}$.

- **المطلوب:** برهن هندسياً أنّ $\lim_{x\to 0} \frac{\sin x}{x} = 1$.

- **الحل:**

١. للمقارنة في الربع الأول: $\sin x < x < \tan x$.

٢. القسمة على $\sin x$: $1 < \dfrac{x}{\sin x} < \dfrac{1}{\cos x}$.

٣. بالمعكوس: $\cos x < \dfrac{\sin x}{x} < 1$، وبما أنّ $\cos x \to 1$ فبحلقة القص (لاحقاً 5.7) النهاية $= 1$. ■

- **النتيجة:** $\lim_{x\to 0}\frac{\sin x}{x}=1$ — واحدة من أهمّ النهايات المرجعية.

- **الربط بالذكاء الاصطناعي:** GELU: $\mathrm{GELU}(x)=x\,\Phi(x)\approx\frac{x}{2}\left[1+\tanh\!\left(\sqrt{2/\pi}(x+0.0447x^3)\right)\right]$؛ تحليل سلوكها القرب من الصفر يستخدم هذا الحدّ (ذات الحدين $\sin x\approx x$).

مثال (7-2.7).

- **المعطيات:** $f(x)=e^{-1/x^2}$ مع تعريف $f(0)=0$.
- **المطلوب:** برهن أنّ $\lim_{x\to 0}f(x)=0$.
- **الحل:**

١. لكل $\varepsilon>0$: $e^{-1/x^2}<\varepsilon \iff -1/x^2<\ln\varepsilon \iff x^2<\frac{-1}{\ln\varepsilon}$ (للـ $\varepsilon<1$).

٢. نختار $\delta=\sqrt{\dfrac{-1}{\ln\varepsilon}}$.

٣. حينها $|x|<\delta\Rightarrow f(x)<\varepsilon$. ■

- **النتيجة:** النهاية 0، هذه «الدالة المسطّحة» الشهيرة.

- **الربط بالذكاء الاصطناعي:** هذه الدالة متصلة (بل سلسة!) عند 0 لكنّ كل اشتقاقها أعلى فيها 0 — نموذج «الوادي المسطّح» الذي يُربِك محسّنات التدرّج ويقود لمنهجيات Sharpness-Aware Minimization.

مثال (8-2.7).

- **المعطيات:** $f(x)=\dfrac{x^2-1}{x-1}$.
- **المطلوب:** $\lim_{x\to 1}f(x)$ مع أنّ $f(1)$ غير معرّفة.
- **الحل:**

١. $x\neq 1$ إذن $f(x)=x+1$ (اختزال جبري مسموح لأنّ التعريف يستثني a).

٢. النهاية $=2$.

٣. قيمة $f(1)$ لا تدخل في التعريف أصلاً. ■

- **النتيجة:** النهاية $2=$ رغم عدم التعريف عند النقطة.

- **الربط بالذكاء الاصطناعي:** «الثقب القابل للاختزال» هو نفسه حالة $y=\hat{y}-\hat{y}$ الناتجة عن قناع softmax الداخلي؛ نُعيد تعريف الدالة عند النقطة لنسدّ الثقب دون تغيير السلوك القرب.

مثال (7.2-9).

- **المعطيات:** $f(x) = x \sin \frac{1}{x}$ (مع $f(0)$ غير معرّفة).
- **المطلوب:** برهن $\lim_{x \to 0} f(x) = 0$ (نظرية الضغط/الحصر).
- **الحل:**

١. $-|x| \leq x \sin \frac{1}{x} \leq |x|$ لأنّ $\left|\sin \frac{1}{x}\right| \leq 1$.

٢. الطرفان $\to 0$، فبالحصر الوسط $\to 0$. ■

- **النتيجة:** النهاية 0 بالحصر بين دالّتين.

- **الربط بالذكاء الاصطناعي:** «التذبذب السريع المضبوط بِسوَار» هو صورة التدرّجات الثابتة الاتجاه على الدُفعات (batch) التي يتلاشى حجمها كـ $O(\sqrt{k})$ بينما النشاز (noise) يتلاشى أسرع.

مثال (7.2-10).

- **المعطيات:** $f(x) = \begin{cases} x + 1 & x < 2 \\ 5 - x & x > 2 \end{cases}$
- **المطلوب:** النهايات الأحادية وحدد وجود النهاية.
- **الحل:**

١. يساراً: $\lim_{x \to 2^-} (x + 1) = 3$.

٢. يميناً: $\lim_{x \to 2^+} (5 - x) = 3$.

٣. تساويَا $\Longrightarrow$ النهاية $= 3$. ■

- **النتيجة:** النهاية موجودة $= 3$ (الدالة إبرّة بقمة عند 2 إذا عرّفنا $f(2) = 3$).

- **الربط بالذكاء الاصطناعي:** دالة الخسارة ReLU المركّبة «إبرّة» مشابهة عند قيم الشبكة الحرجة؛ الاتصال يكفي لتعريف الشبه-اشتقاق (Clarke) المستخدم في محسّنات التدرّج المتقطّع.

مثال (7.2-11).

- **المعطيات:** $f(x) = \begin{cases} 1 & x \in \mathbb{Q} \\ 0 & x \notin \mathbb{Q} \end{cases}$ (دالة ديريشليه).
- **المطلوب:** أين توجد النهاية؟

- **الحل:**

١. عند أيّ a: في كل جوار δ يوجد عددين ونسبيّ.

٢. اخترنا L أيّ ما كان: $\varepsilon = \frac{1}{3}$ تفشل لأنّ قيمتين تختلفان بمقدار 1 داخل الجوار.

٣. إذن النهاية لا توجد عند أي نقطة. ■

- **النتيجة:** دالة ديريشليه بلا نهايات في أي مكان.

- **الربط بالذكاء الاصطناعي:** تذكير بأنّ «متصلة في كل نقطة» ليست بديهية؛ الشبكات العصبية ذات التنشيط المستمر (ReLU/ELU/GELU) متصلة تعريفياً — وهذه خاصية نستثمرها في براهين الشمول العالمي.

مثال (12-2.7).

- **المعطيات:** $f(x) = \sqrt{x}$ عند $a = 0$.
- **المطلوب:** النهاية اليمنى بتعريف ϵ–δ.
- **الحل:**

١. لكل $\varepsilon > 0$: $0 \le x < \varepsilon^2 \iff |\sqrt{x} - 0| < \varepsilon$.

٢. نختار $\delta = \varepsilon^2$ (ونقيّد المجال $x \ge 0$). ■

- **النتيجة:** $\lim_{x \to 0^+} \sqrt{x} = 0$.

- **الربط بالذكاء الاصطناعي:** دوال الجذر (RMSNorm) لها نهاية يمينية عند الصفر؛ كسور المقياس $\sqrt{\text{mean}(x^2) + \epsilon}$ تضيف ϵ بالضبط لأنّ المشتقق عند 0 يسبب عدم استقرار عددي — جسر مباشر إلى الفصل السابق.

مثال (13-2.7).

- **المعطيات:** $f(x) = \dfrac{1}{x}$ عند $a = 0$.
- **المطلوب:** أثبت عدم وجود النهاية اليمنى (انفجار).
- **الحل:**

١. خذ $\varepsilon = 1$: مهما كان δ اخترنا $x = \min(\delta/2,\ 10^{-6})$.

٢. حينها $f(x) > 10^6 > 1$ لكل اختيار عملي، والحدّ لا يمكن تحقيقه لأيّ L منته. ■

- **النتيجة:** $\lim_{x \to 0^+} \frac{1}{x} = +\infty$ بالمعنى الموسّع — لا نهاية منتهية.

- **الربط بالذكاء الاصطناعي:** خسارة الانتروبيا المتقاطعة عند احتمال متوقَّع $p \to 0^+$ تنفجر كـ $-\log p \to \infty$؛ ولهذا نستخدم clipping الاحتمالات ($p_{\min} = 10^{-8}$ في keras).

مثال (7.2-14).

- **المعطيات:** $f(x) = \dfrac{|x|}{x}$، $x \neq 0$.
- **المطلوب:** النهايات الأحادية عند 0.
- **الحل:**

١. $x \to 0^+ : f = 1$. ٢. $x \to 0^- : f = -1$.

٢. مختلفتان $\Longrightarrow$ لا نهاية. ■

- **النتيجة:** قفزة من -1 إلى $+1$.
- **الربط بالذكاء الاصطناعي:** هذه قفزة دالّة الإشارة مغلفة؛ توضّح لماذا لا يصلح الاتصال وحده لضمان «سلاسة» مسار التعلم — نحتاج تمييز الاتصال عن قابلية الاشتقاق (قسم 4.7).

مثال (7.2-15).

- **المعطيات:** $f(x) = e^x$ عند $a = 0$.
- **المطلوب:** برهن $\lim_{x\to 0} e^x = 1$ باستخدام تعريف النهاية.
- **الحل:**

١. $|e^x - 1| < \varepsilon \iff -\ln(1+\varepsilon) < x < \ln(1+\varepsilon)$ (لـ $\varepsilon > 0$).

٢. نختار $\delta = \ln(1 + \varepsilon/2)$، وهو موجب دائماً.

٣. حينها $|x| < \delta \Rightarrow |e^x - 1| < \varepsilon/2 < \varepsilon$. ■

- **النتيجة:** النهاية $1 =$ بـ $\delta = \ln(1 + \varepsilon/2)$.
- **الربط بالذكاء الاصطناعي:** دوالّ sigmoid و softmax كلّها تركيبات من e^x، استمرارية e^x هي الذي يضمن أنّ «تغيّراً صغيراً في logits يعطي تغيّراً صغيراً في الاحتمالات» — وهو مبدأ استقرار الخرج الذي نعتمده في التدريب.

النظرية

dir="ltr"> <div
then: (finite), $\lim_{x\to a} g(x) = M$ and $\lim_{x\to a} f(x) = L$ If **Laws). (Limit 1.3.7 Theorem**

(2.7)

$$\lim(f \pm g) = L \pm M, \quad \lim(fg) = LM, \quad \lim \frac{f}{g} = \frac{L}{M}\ (M \neq 0), \quad \lim \sqrt{f} = \sqrt{L}\ (L \geq 0)$$

حالات عدم التعيين السبع

الصيغة	النوع	الأداة المفضّلة
$\frac{0}{0}$	كثيرات/جذور/لوغاريتمات	التحليل أو لوبيتال (فصل لاحق) أو تطوير تايلور
$\frac{\infty}{\infty}$	كسور أنموذجية	القسمة على أعلى قوة، تايلور
$0 \cdot \infty$	نواتج متعارضة	تحويلها إلى $\frac{0}{0}$ أو $\frac{\infty}{\infty}$
$\infty - \infty$	فروق متلاصقة	الدمج والتحليل أو المضاعفة بالمرافق
1^∞	أسّية مركّبة	الحدّ e عبر $\exp(\ln(\cdot))$
0^0	الأسّية عند الحدود	نفس تقنية اللوغاريتم
∞^0	أسّية مقلوبة	نفس تقنية اللوغاريتم

مثال تفسيري للحالة 1^∞

$$\lim_{n\to\infty}\left(1+\frac{1}{n}\right)^{n} = e \tag{3.7}$$

برهان موجز.

خذ اللوغاريتم: $\ln = n\ln(1+\frac{1}{n})$. بما أنّ $\ln(1+t) = t + O(t^2)$ فإنّ الحدّ $= n\cdot(\frac{1}{n} + O(\frac{1}{n^2}))$ $= 1 + O(\frac{1}{n}) \to 1$، فالنهاية $= e^1 = e$. ■

- **الربط بالذكاء الاصطناعي:** هذه الحدّية هي أصل «توزيع بواسون كحدّ ذي الحدين»، الذي يُستخدم في نمذجة عدد الأحداث النادرة في التسريّب dropout) بالبواسون) وفي لاسو (الانحدار اللوجستي كنموذج حدّي).

أخطاء شائعة في قوانين النهايات

الخطأ	لماذا خطأ	التصحيح
$\lim(f+g) = \lim f + \lim g$ دائماً	يتطلّب وجود النهايتين (منتهيتين)	تحقّق من الوجود أولاً؛ وإلا استخدم الجبر
«كلّ $\frac{0}{0}$ صفر»	غير معرّفة قبل التبسيط	حلّل أو لوبتال أو تايلور
$\lim(1+1/n)^n = 1$	«الأساس $1 \to$ فالنتيجة 1» خطأ لأنّ الأس $\to \infty$	حالات 1^∞ تحتاج اللوغاريتم
قسمة البسط والمقام على n في $\frac{\infty}{\infty}$ بإهمال الدرجات الأدنى	قد تعطي نتيجة خاطئة في غير المتسلسلات	قسّم على أعلى قوة فعّالة

أمثلة محلولة على قوانين النهايات (15 مثالاً)

مثال (3.7-1).

- **المعطيات:** $\lim_{x\to 2}\dfrac{x^2-4}{x-2}$.
- **المطلوب:** احسب النهاية.
- **الحل:**

١. التعويض يعطي $\frac{0}{0}$.

٢. التحليل: $\frac{(x-2)(x+2)}{x-2} = x+2$ (مسموح لأنّ $x \neq 2$).

٣. النهاية $= 4$. ■

- **النتيجة:** 4.
- **الربط بالذكاء الاصطناعي:** هذا «الميل القاطع المتحول لميل مماسي» — جوهر تعريف المشتقّ في الفصل القادم.

مثال (7.3-2).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{3x^2+5x-1}{6x^2-2x+7}$.
- **المطلوب:** النهاية.
- **الحل:**

١. قسمة على x^2: $\frac{3+5/x-1/x^2}{6-2/x+7/x^2}$.

٢. كل حدّ فيه $1/x \to 0$.

٣. النهاية $= 3/6 = \frac{1}{2}$. ■

- **النتيجة:** $\frac{1}{2}$ — الدرجتان متساويتان فنأخذ نسبة المعاملين القياديين.
- **الربط بالذكاء الاصطناعي:** نسبة المعاملات القيادية تحكم «تضخّم» الخسارة مع الدُفعة الكبيرة (scaling laws): سلوك الذيل يحدّه الحدّ القيادي.

مثال (7.3-3).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{2x^2+x}{x^3-1}$.
- **المطلوب:** النهاية.
- **الحل:**

١. المقام أعلى درجة $\Longrightarrow$ القسمة على x^3: $\frac{2/x+1/x^2}{1-1/x^3}$.

٢. البسط $0 \to$ والمقام $1 \to$.

٣. النهاية $= 0$. ■

- **النتيجة:** 0 — المقام «يهزم» البسط.
- **الربط بالذكاء الاصطناعي:** تلاشي التدرّج في دوالّ التشبع هو نفس النمط: البسط شبه ثابت والمقام ينمو.

مثال (7.3-4).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{\sqrt{x^2+3x}}{x}$، $x \to +\infty$.
- **المطلوب:** النهاية.
- **الحل:**

١. $\sqrt{x^2+3x} = x\sqrt{1+3/x}$ (لأنّ $x>0$).

٢. النهاية $= \sqrt{1+0} = 1$. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** مسافة Norm (الفصل 5): $\|v+\delta\|_2/\|v\|_2 \to 1$ عند التشويش الصغير — أساس براهين الاستقرار للضوضاء اللاإرادية.

مثال (٧.٣-5).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{\sqrt{x^2+3x}}{x}$، $x \to -\infty$.
- **المطلوب:** النهاية على الفرع السالب.
- **الحل:**

١. الآن $x<0$ فحين الخروج من الجذر: $\sqrt{x^2+3x} = |x|\sqrt{1+3/x} = -x\sqrt{1+3/x}$.

٢. النسبة $= -\sqrt{1+3/x} \to -1$.

٣. النهاية $= -1$. ■

- **النتيجة:** -1 — تغيّر إشارة بسبب $|x|$.
- **الربط بالذكاء الاصطناعي:** تذكير: «استخراج x من جذر تربيعي» يفرض $|x|$؛ خطأ شائع في الشيفرة عند التعامل مع تدرّجات سالبة.

مثال (٧.٣-6).

- **المعطيات:** $\lim_{x\to 0} \dfrac{\sqrt{x+9}-3}{x}$.
- **المطلوب:** النهاية $\left(\frac{0}{0}\right)$.
- **الحل:**

١. المضاعفة بالمرافق: $\frac{1}{\sqrt{x+9}+3} = \frac{(x+9)-9}{x(\sqrt{x+9}+3)}$.

٢. التعويض: $\frac{1}{6}$. ■

- **النتيجة:** $\frac{1}{6}$.
- **الربط بالذكاء الاصطناعي:** المرافق هو «الاختزال الشرطي» الذي نطبّقه لتفادي الإلغاء العددي الكارثي (فصل 6): $\sqrt{x+9}-3$ يُحسب في العدّة كـ 0؛ الشكل المُعاد كتابته يُحسب بدقّة.

مثال (7-3.7).

- **المعطيات:** $\lim_{x\to\infty}\left(\sqrt{x^2+x}-x\right)$.
- **المطلوب:** نهاية من نوع $\infty-\infty$.
- **الحل:**

١. المضاعفة بالمرافق: $\frac{x}{\sqrt{x^2+x}+x}$.

٢. قسمة على x: $\frac{1}{\sqrt{1+1/x}+1}\to\frac{1}{2}$.

٣. النهاية $=\frac{1}{2}$. ■

- **النتيجة:** $\frac{1}{2}$.

- **الربط بالذكاء الاصطناعي:** فرق أنموذجي بين «الخسارة الظاهرية» ومكوّن تنظيم: مصطلحات كبيرة متقاربة تُلغي بعضها وتبقى صيغة النصف — لا تُحسب مباشرة في fp16.

مثال (8-3.7).

- **المعطيات:** $\lim_{x\to 0^+} x\ln x$.
- **المطلوب:** نهاية من نوع $0\cdot\infty$.
- **الحل:**

١. اكتب $x\ln x=\frac{\ln x}{1/x}$ (نوع $\frac{\infty}{\infty}$).

٢. بلوبتال (أو المعرفة بأنّ $\ln$ يهزم القوى): $\frac{1/x}{-1/x^2}=-x\to 0$.

٣. النهاية $=0$. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** $p\log p\to 0$ عند $p\to 0^+$ يضمن أنّ الإنتروبيا محدودة على المدخل المتطرف — أساس برهان $H\le\log n$ القادم في فصل الإنتروبيا.

مثال (9-3.7).

- **المعطيات:** $\lim_{x\to\infty}\left(1+\frac{2}{x}\right)^{3x}$.
- **المطلوب:** نهاية من نوع 1^∞.

- **الحل:**

١. خذ اللوغاريتم: $3x\ln(1+2/x) \approx 3x \cdot \frac{2}{x} = 6$.

٢. النهاية $= e^6$. ■

- **النتيجة:** $e^6 \approx 403.43$.

- **الربط بالذكاء الاصطناعي:** «نموّ مركّب» بهذا الشكل يصف تضاعف حجم بيانات التدريب والقدرة في قوانين التوسّع :(Chinchilla) لوغاريتم الحدّ خطّي في المعاملات.

مثال (7.3-10).

- **المعطيات:** $\lim_{x\to 0}(1+3x)^{1/x}$.

- **المطلوب:** النهاية.

- **الحل:**

١. اللوغاريتم: $\frac{\ln(1+3x)}{x} \to 3$ (لأنّ $\ln(1+t) \approx t$).

٢. النهاية $= e^3$. ■

- **النتيجة:** $e^3 \approx 20.09$.

- **الربط بالذكاء الاصطناعي:** «التضاعف الأُسّي بمعدّل لحظي» يصف تراكم الفائدة في regularization من نوع $e^{\lambda x}$؛ ولهذا نستخدم log-space في softmax.

مثال (7.3-11).

- **المعطيات:** $\lim_{x\to 0^+} x^x$.

- **المطلوب:** نهاية من نوع 0^0.

- **الحل:**

١. اللوغاريتم: $x\ln x \to 0$ (مثال 7.3-8).

٢. النهاية $= e^0 = 1$. ■

- **النتيجة:** 1.

- **الربط بالذكاء الاصطناعي:** توزيع «خريطة الحرارة الناعمة» عند الحرارة المرتفعة (temperature $\to \infty$) يقارب التوزيع المنتظم؛ هذه النهاية تظهر في التراجع $0^0 = 1$ المقبول في تعريفات كثيرات الحدود المولّدة.

مثال (7.3-12).

- **المعطيات:** $\lim_{x\to 0} \dfrac{\sin(5x)}{\sin(2x)}$.
- **المطلوب:** النهاية.
- **الحل:**

١. اكتب: $\frac{5}{2} \cdot \frac{2x}{\sin 2x} \cdot \frac{\sin 5x}{5x}$.

٢. كل قوس $\to 1$.

٣. النهاية $= \frac{5}{2}$. ■

- **النتيجة:** $\frac{5}{2}$.

- **الربط بالذكاء الاصطناعي:** «العمود الفقري» $\sin(kx)/(kx) \to 1$ يقابل «التطبيع بالمعدّل» في positional encoding الجيبي؛ المعامل النسبي هو المتبقّي.

مثال (7.3-13).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{x^2 \sin(1/x)}{x}$.
- **المطلوب:** النهاية.
- **الحل:**

١. اكتب: $x \cdot \dfrac{\sin(1/x)}{1/x}$.

٢. القوس $1 \to$ والمقدار الخارجي $\to \infty$.

٣. النهاية $= \infty$ (انبثاق). ■

- **النتيجة:** $+\infty$.

- **الربط بالذكاء الاصطناعي:** تحذير أنّ «خطأً صغيراً مضروباً بعامل كبير» قد ينفجر؛ يجسّد خطر إعادة القياس بعد الضرب بعوامل كبيرة في fp16.

مثال (7.3-14).

- **المعطيات:** $\lim_{x\to 1} \dfrac{\ln x}{x-1}$.
- **المطلوب:** النهاية $\left(\frac{0}{0}\right)$.

- **الحل:**

١. ضع $t = x - 1$: $\frac{\ln(1+t)}{t} \to 1$ (الحدّ المرجعي).

٢. النهاية $= 1$. ■

- **النتيجة:** 1.

- **الربط بالذكاء الاصطناعي:** هذا الحدّ هو «مشتقّ ln عند 1»، ويظهر في divergence: KL $(p \| q)$ — التقريب الخطّي $\ln(p/q) \approx (p-q)/q$ في تحليل الاستقرار للتوزيعات.

مثال (15-3.7).

- **المعطيات:** $\lim_{n\to\infty} \left(\frac{n}{n+1}\right)^n$.

- **المطلوب:** النهاية (1^∞).

- **الحل:**

١. اللوغاريتم: $n \ln \frac{n}{n+1} = n \ln\left(1 - \frac{1}{n+1}\right) \approx n \cdot \left(-\frac{1}{n}\right) = -1$.

٢. النهاية $= e^{-1}$. ■

- **النتيجة:** $e^{-1} \approx 0.368$.

- **الربط بالذكاء الاصطناعي:** احتمال عدم اختيار عنصر معيّن في dropout المعياري $(1-p)^n \to e^{-pn}$ — أساس تحليل توقّع عدد الوحدات الناجية في dropout.

النظرية

dir="ltr"> <div

ffi: a at continuous is f **point). a at (Continuity 1.4.7 Definition**

$$\lim_{x \to a} f(x) = f(a).$$

agree. two the and defined, is $f(a)$ (finite), exists limit the is, That

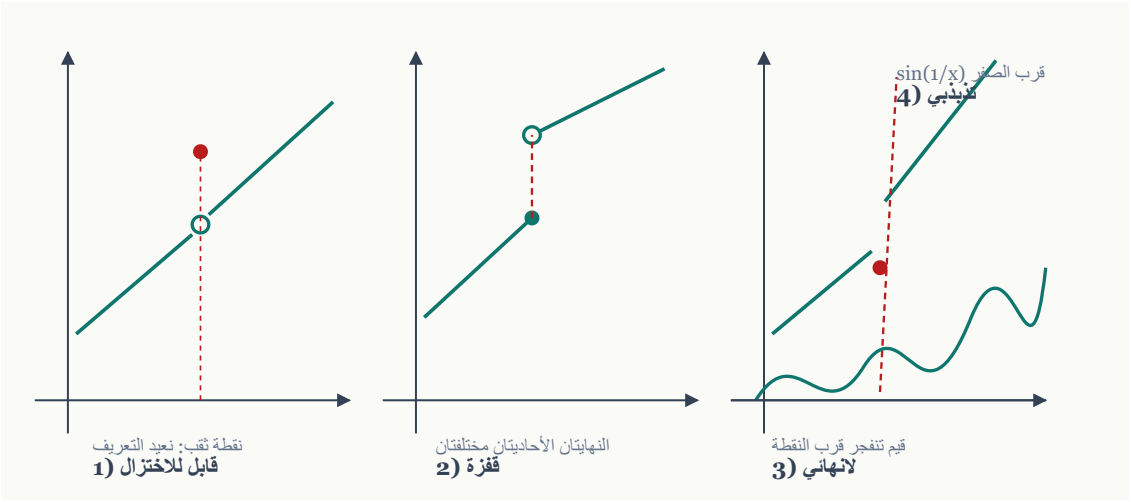
$$f \text{ متصلة عند } a \iff \lim_{x\to a^-} f(x) = \lim_{x\to a^+} f(x) = f(a) \tag{4.7}$$

الاتصال على مجموعة = الاتصال عند كل نقطة فيها.

أنواع الانقطاع الأربعة

النوع	السبب	هل يمكن «إصلاحه» بإعادة تعريف نقطة؟
قابل للاختزال (removable)	النهاية موجودة لكن $f(a)$ غائبة أو مخالفة	نعم
قفزة (jump)	النهايتان الأحاديتان موجودتان ومختلفتان	لا
لانهائي (infinite)	قيم تنفجر قرب النقطة	لا
تذبذبي (oscillatory)	القيم تتذبذب بلا استقرار	لا

<figure> الشكل<figcaption> 2.7: أنواع الانقطاع الأربعة. فقط النوع الأول يُسدّ بإعادة تعريف النقطة؛ الثلاثة الأخرى تعيبات بنيوية في الدالة.</figcaption> </figure>



شكل ٢.٧: *
أنواع الانقطاع الأربعة

أخطاء شائعة في الاتصال

الخطأ	لماذا خطأ	التصحيح
«متصلة يعني قابلة للاشتقاق»	$\lvert x\rvert$ متصلة عند 0 وغير قابلة للاشتقاق	الاتصال أضعف من قابلية الاشتقاق
«المجموع غير متصل بالضرورة»	إن كانت كلتاهما متصلتين فمجموعهما متصل	الانقطاع يظهر في الحاصل أو عند نقاط النقاط الحرجّة فقط
إهمال فحص $f(a)$ نفسها	النهاية قد توجد و $f(a)$ غائبة	المعادلة (4.7) تتطلّب الأطراف الثلاثة
«دالة متصلة تبلغ قيمها كلها»	فقط على المجموعات المغلقة المحدودة (نظرية 2.5.7)	انتبه للمجال

أمثلة محلولة على الاتصال (15 مثالاً)

مثال (4.7-1).

- **المعطيات:** $f(x) = x^2 + 3$.
- **المطلوب:** أثبت الاتصال عند $x = 2$ بتعريف ϵ–δ.
- **الحل:**

١. $f(2) = 7$.

٢. $|f(x) - 7| = |x^2 - 4| = |x - 2||x + 2|$؛ نقيد $|x - 2| < 1 \Rightarrow |x + 2| < 7$.

٣. اختر $\delta = \min(1, \varepsilon/7) \Longrightarrow$ متصلة. ■

- **النتيجة:** متصلة عند 2.

- **الربط بالذكاء الاصطناعي:** كثيرات الحدود متصلة كلّها — دوال الخسارة كثيرات في المعاملات (الانحدار الخطّي) لا تحدث انقطاعات أصلاً؛ المصدر الوحيد للانقطاع هو دوال التنشيط والعمليات اللاخطية.

مثال (7.4-2).

- **المعطيات:** $f(x) = \dfrac{x^2 - 9}{x - 3}$ مع تعريف $f(3)$ غير موجود.
- **المطلوب:** صنّف الانقطاع.
- **الحل:**

١. النهاية $\lim(x + 3) = 6 =$ موجودة.

٢. $f(3)$ غير معرّفة.

٣. انقطاع **قابل للاختزال**، نضع $f(3) = 6$ لنسدّه. ■

- **النتيجة:** انقطاع اختزالي عند 3.

- **الربط بالذكاء الاصطناعي:** الحالة النموذجية «division by zero» عند نقطة واحدة» في دوال التقييم، الحل البرمجي المعتاد (clipping أو epsilon) هو إعادة تعريف نقطة.

مثال (7.4-3).

- **المعطيات:** $f(x) = \begin{cases} x^2 & x \le 1 \\ 2x + 1 & x > 1 \end{cases}$
- **المطلوب:** إيجاد قيم a التي تجعل الدالة متصلة (بشكل عام $f(x) = \begin{cases} x^2 & x \le a \\ 2x + 1 & x > a \end{cases}$).
- **الحل:**

١. الشرط: $a^2 = 2a + 1$.

٢. حلّ: $a^2 - 2a - 1 = 0 \Rightarrow a = 1 \pm \sqrt{2}$.

٣. عند $a = 1$ الأصلي: النهايتان 1 و 3 مختلفتان $\Longrightarrow$ قفزة. ■

- **النتيجة:** عند $a = 1$ انقطاع قفزة، الاتصال يتحقق فقط عند $a = 1 \pm \sqrt{2}$.

- **الربط بالذكاء الاصطناعي:** «مطابقة الطرفين» هو شرط وصل الطبقات في الشبكات المجزّأة (mixture of experts) عندما تتطلب خرجاً متصلاً عند حدود الإسناد.

مثال (7.4-4).

- **المعطيات:** $f(x) = \dfrac{1}{x - 2}$.

- **المطلوب:** صنّف الانقطاع عند 2.
- **الحل:**

١. $\lim_{x\to 2^+} = \infty$، $\lim_{x\to 2^-} = -\infty$.

٢. انقطاع **لانهائي** (خطّ عمودي مقارب). ■

- **النتيجة:** لانهائي عند 2.

- **الربط بالذكاء الاصطناعي:** $-\log p$ عند $p \to 0^+$؛ خسارة cross-entropy لانهائية الانقطاع نظرياً، ولهذا clipping الاحتمالات (10^{-8}) ضرورة عملية لا ترف.

مثال (7.4-5).

- **المعطيات:** $f(x) = \sin\frac{1}{x}$.
- **المطلوب:** صنّف الانقطاع عند 0 (الدالة غير معرّفة هناك).
- **الحل:**

١. في كل جوار للصفر تتذبذب القيم بين -1 و 1 بلا استقرار.

٢. لا نهاية يمنى/يسرى.

٣. انقطاع **تذبذبي**. ■

- **النتيجة:** تذبذبي عند 0.

- **الربط بالذكاء الاصطناعي:** التذبذب عالي التردد في الخسارة عند rates learning كبيرة هو صورة سلوكية لهذا الانقطاع؛ الحل زيادة الدقّة أو تجانس الدُفعات.

مثال (7.4-6).

- **المعطيات:** $f(x) = \text{ReLU}(x) = \max(0, x)$.
- **المطلوب:** افحص الاتصال والقابلية للاشتقاق عند 0.
- **الحل:**

١. $\lim_{x\to 0^-} = 0 = \lim_{x\to 0^+} = f(0) \implies$ متصلة.

٢. الميل الأيسر $0 =$ والأيمن $1 = \implies$ غير قابلة للاشتقاق.

٣. انقطاع **في المشتقّ** لا في الدالة (زاوية). ■

- **النتيجة:** متصلة، غير قابلة للاشتقاق عند 0.

- **الربط بالذكاء الاصطناعي:** القلب النابض للشبكات الحديثة؛ الانتشار العكسي يستخدم subgradient ويعمل عملياً — الاتصال وحده يضمن أنّ الشبكة كلّها متصلة كدالة للمدخلات.

مثال (7-4.7).

- **المعطيات:** $f(x) = \begin{cases} \dfrac{\sin x}{x} & x \neq 0 \\ a & x = 0 \end{cases}$
- **المطلوب:** أوجد a التي تجعل f متصلة عند 0.
- **الحل:**

١. النهاية $= 1$ (مثال 6-2.7).

٢. الشرط $a = 1$. ■

- **النتيجة:** $a = 1$.

- **الربط بالذكاء الاصطناعي:** نمط «ملء الثقب» يظهر في تعريف GELU عند الحدّ: يعتمد التنفيذ القيم الحدّية المسجلة مسبقاً للنقاط الحرجة.

مثال (8-4.7).

- **المعطيات:** $f(x) = \dfrac{1}{1+e^{-x}}$ (sigmoid).
- **المطلوب:** افحص الاتصال على $\mathbb{R}$.
- **الحل:**

١. تركيب e^x المتصلة، مع $x \mapsto -x$، جمع، قسمة بمقام لا يصفري $(1 + e^{-x} \geq 1)$.

٢. تركيب دوال متصلة بلا استثناءات $\Longrightarrow$ متصلة على كل $\mathbb{R}$. ■

- **النتيجة:** متصلة في كل مكان.

- **الربط بالذكاء الاصطناعي:** هذا سبب تفضيل sigmoid في التدرّج مباشرةً بدل العتبة الصلبة: الاتصال الكلي يضمن استمرار التدرّجات على كل المدخلات.

مثال (9-4.7).

- **المعطيات:** $f(x) = \lfloor x \rfloor$ (دالة الجزء الصحيح).
- **المطلوب:** صنّف الانقطاع عند $x = 1$.
- **الحل:**

١. $\lim_{x \to 1^-} = 0$، $\lim_{x \to 1^+} = 1 = f(1)$.

٢. النهايتان مختلفتان بمقدار 1 $\Longrightarrow$ **قفزة.** ■

- **النتيجة:** قفزة عند كل عدد صحيح.

- **الربط بالذكاء الاصطناعي:** المُجدوِل (scheduler) الذي يخفض rate learning خطوة كل 10 حقب له نفس السلوك القفزي؛ الجدولة الكونية (cosine) تحوّله لدالة متصلة.

مثال (7.4-10).

- **المعطيات:** $f(x) = \dfrac{x \sin x}{x^2 + 1}$.

- **المطلوب:** أثبت الاتصال على $\mathbb{R}$.

- **الحل:**

١. $\sin x$ متصلة، x متصلة، حاصل ضرب متصل، المقام > 0 دائماً فالحاصل متصل.

٢. بلا نقاط استثناء $\Longrightarrow$ متصلة كلّياً. ■

- **النتيجة:** متصلة على $\mathbb{R}$.

- **الربط بالذكاء الاصطناعي:** دالة «سقف ناعم» تُستخدم في تقدير الاهتمام المحايد؛ استمراريتها المضمونة بنيوياً تجنّبنا فحص نقاط حرجة.

مثال (7.4-11).

- **المعطيات:** $f(x) = \begin{cases} e^{-1/x^2} & x \neq 0 \\ 0 & x = 0 \end{cases}$

- **المطلوب:** افحص الاتصال عند 0.

- **الحل:**

١. النهاية $0 =$ (مثال 7.2-7).

٢. $f(0) = 0 \Longrightarrow$ متصلة (بل سلسة — كل اشتقاقاتها عند 0 صفر). ■

- **النتيجة:** متصلة عند 0 وسلسة.

- **الربط بالذكاء الاصطناعي:** دوالّ «الوادي المسطّح»؛ الاتصال السلس لا يعني سهولة التحسين — شكل الوادي مهمّ لا السلاسة وحدها.

مثال (7.4-12).

- **المعطيات:** $f(x) = |x-1| + |x-3|$.
- **المطلوب:** نقاط عدم قابلية الاشتقاق مع الاتصال.
- **الحل:**

١. مجموع قدر مطلق متصل؛ انقطاعات الدالة: لا شيء.

٢. عند $x = 1$ و $x = 3$ زوايا (ميل أيسر $\neq$ أيمن) $\Longrightarrow$ غير قابلة للاشتقاق هناك فقط.

٣. الاتصال كامل، الاشتقاق ناقص عند نقطتين. ■

- **النتيجة:** متصلة، زاويتان عند 1 و 3.
- **الربط بالذكاء الاصطناعي:** خسارة L1 لهذا الشكل تماماً، نقاط الزاوية هي «ما تجنّبه خسارة «Huber بالتهيد بين L2 و L1.

مثال (7.4-13).

- **المعطيات:** $f(x) = \begin{cases} x \sin \frac{1}{x} & x \neq 0 \\ 0 & x = 0 \end{cases}$
- **المطلوب:** افحص الاتصال عند 0.
- **الحل:**

١. النهاية $= 0$ بالحصر (مثال 7.2-9).

٢. $f(0) = 0 \Longrightarrow$ متصلة. ■

- **النتيجة:** متصلة عند 0 (رغم التذبذب الداخلي).
- **الربط بالذكاء الاصطناعي:** «تذبذب مغلوب بالسِوار» يصف ضجيج SGD: متوسط المسار متصل وسلس بينما المسار الفعلي يتذبذب — أساس متوسط الأوزان (weight averaging / SWA).

مثال (7.4-14).

- **المعطيات:** $f(x) = \dfrac{x^2 \sin(1/x)}{x}$، $x \neq 0$ (أي $f(x) = x \sin \frac{1}{x}$) مركّبة مع $g(x) = f(x) + x$.
- **المطلوب:** هل يمكن لمجموع دالتين متصلتين أن يكون غير متصل؟
- **الحل:**

١. f متصلة (مثال سابق) و x متصلة.

٢. المجموع g متصل — لا يوجد مثال مضاد.

٣. الاتصال مغلوق تحت الضرب في ثابت والجمع والتركيب. ■

- **النتيجة:** لا، الجمع يحافظ على الاتصال.
- **الربط بالذكاء الاصطناعي:** الخسارة الكلية $L = L_{\text{data}} + \lambda L_{\text{reg}}$ متصلة إذا كانت مكوّناتها كذلك — الانقطاع الوحيد ممكن من العمليات اللاخطية العتبية.

مثال (7.4-15).

- **المعطيات:** $f(x) = \begin{cases} \dfrac{e^x - 1}{x} & x \neq 0 \\ a & x = 0 \end{cases}$
- **المطلوب:** قيمة a للاستمرارية، ثم قيمة قريبة من المشتقّ عند 0.
- **الحل:**

١. $e^x = 1 + x + \frac{x^2}{2} + \cdots \implies \frac{e^x - 1}{x} \to 1$.

٢. إذن $a = 1$.

٣. لاحظ أنّ الحدّ نفسه هو e^0 (مشتقّ e^x) — الجسر إلى الفصل القادم. ■

- **النتيجة:** $a = 1$؛ الحدّ يساوي مشتقّ e^x عند الصفر.

- **الربط بالذكاء الاصطناعي:** «استقرار expm1» — المكتبات تستخدم expm1 تحديداً لتجنّب فقدان دقّة هذا الحدّ عند x صغيرة (استمرار مع الفصل 6: الإلغاء الكارثي).

النظريات

dir="ltr"> <div
Theorem Value (Intermediate 1.5.7 Theorem (Bolzano). — If f is continuous on $[a, b]$, $f(a) \cdot f(b) < 0$ and $c \in (a, b)$ with $f(c) = 0$ exists there.

$$f \in C[a,b],\ f(a)f(b) < 0 \implies \exists\, c \in (a,b) : f(c) = 0 \tag{5.7}$$

dir="ltr"> <div
Theorem Value (Extreme 2.5.7 Theorem). A function continuous on a closed bounded interval $[a, b]$ attains a maximum and a minimum.
Theorem Value (Mean 3.5.7 Theorem for mean-value form, integrals for continuous functions). For $f \in C[a, b]$ and any value Y between $f(a)$ and $f(b)$, there exists $c \in (a, b)$ with $f(c) = Y$.

برهان موجز للبولزانو (بالبحث الثنائي)

١. ثبّت فترة $[a_0, b_0] = [a, b]$ فيها تغيّر إشارة.

٢. افحص المنتصف m: إن كان $f(m) = 0$ انتهينا؛ وإلا اختر النصف الذي يغير الإشارة.

٣. تتكوّن متتالية فترات متداخلة بطول يتنصّف، طولها $\to 0 \implies$ تقارب إلى نقطة وحيدة c.

٤. بالاتصال: $f(c) = 0$. ■

هذا البرهان بنّاء: هو حرفياً خوارزمية Bisection.

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
تطبيق البولزانو على فترة مفتوحة	قد لا يوجد جذر داخل (a,b)	استخدم فترة مغلقة وتغيّر إشارة عند طرفيها
«الاتصال غير ضروري»	دالة قافزة قد تغيّر الإشارة بلا جذر	مثال sgn على $[-1,1]$
«EVT ينجح على فترات غير محدودة»	على $[0,\infty)$ $f(x)=x$ لا يبلغ قيمة قصوى	شرط المغلقة+المحدودة أساسي
الظنّ أنّ EVT يعطي «أين» القيمة القصوى	يعطي الوجود فقط	الموقع يحتاج الفصل 8 (نقاط حرجة)

أمثلة محلولة على نظريات القيم الوسطى (15 مثالاً)

مثال (7.5-1).

- **المعطيات:** $f(x)=x^3-2x-5$ على $[2,3]$.
- **المطلوب:** أثبت وجود جذر في $(2,3)$.
- **الحل:**

١. $f(2)=8-4-5=-1<0$.

٢. $f(3)=27-6-5=16>0$.

٣. f متصلة (كثير حدود) والبولزانو يعطي جذر. ■

- **النتيجة:** جذر وحيد في $(2,3)$ (هذا مثال نيوتن الكلاسيكي).

- **الربط بالذكاء الاصطناعي:** إثبات «وجود حل» قبل البحث عنه عددياً — أساس ضمان توقف الخوارزميات الصرفة في مسائل مساواة الأوزان.

مثال (7.5-2).

- **المعطيات:** $f(x)=x-\cos x$.
- **المطلوب:** أثبت جذر في $(0,1)$.
- **الحل:**

١. $f(0)=-1<0$.

٢. $f(1)=1-\cos 1\approx 0.4597>0$.

٣. البولزانو $\Longrightarrow$ جذر. ■

- **النتيجة:** جذر وحيد (لأنّ $f'=1+\sin x>0$ على $[0,1]$).

- **الربط بالذكاء الاصطناعي:** حلّ معادلات «نقطة التوازن» في آليات الانتباه: نثبت الوجود أولاً بالاتصال، ثم نكرّر التخصيص (fixpoint iteration).

مثال (7.5.3).

- **المعطيات:** $f(x) = x^2$ على $[0, 2]$ والقيمة $Y = 3$.
- **المطلوب:** طبّق نظرية القيمة الوسطى (7.5.3).
- **الحل:**

١. $f(0) = 0 < 4 = f(2)$ و $Y = 3$ بينهما.

٢. $c = \sqrt{3} \in (0, 2)$، $f(c) = 3$. ■

- **النتيجة:** $c = \sqrt{3}$.
- **الربط بالذكاء الاصطناعي:** «إدراج قيمة وسيطة» هو جوهر الاستيفاء (interpolation) بين تضمينات (embeddings): بين متجهي كلمتين نجد متجهاً وسيطاً — الاتصال يضمن عدم «الفراغ».

مثال (7.5.4).

- **المعطيات:** $f(x) = \begin{cases} -1 & x \le 0 \\ 1 & x > 0 \end{cases}$ على $[-1, 1]$.
- **المطلوب:** أثبت فشل البولزانو رغم تغيّر الإشارة.
- **الحل:**

١. $f(-1)f(1) = -1 < 0$.

٢. لكن f غير متصلة عند 0 ولا تساوي صفراً هناك.

٣. لا جذر. ■

- **النتيجة:** الفشل يوضّح ضرورة الاتصال.
- **الربط بالذكاء الاصطناعي:** تذكير بأنّ دوالّ العتبة الصلبة (hard threshold) قد تفوّت الحلول الوسيطة؛ الدوالّ الناعمة تُصلح ذلك نظرياً وعملياً.

مثال (7.5.5).

- **المعطيات:** $f(x) = x^4 - 4x^2 + 4$ على $[-3, 3]$.
- **المطلوب:** أوجد القيم القصوى وفوقها نظرية EVT.
- **الحل:**

١. $f = (x^2 - 2)^2 \ge 0$؛ القيمة الصغرى 0 عند $x = \pm\sqrt{2}$.

٢. القيمة العظمى عند الأطراف: $f(\pm 3) = 81 - 36 + 4 = 49$.

٣. EVT يضمن الوجود؛ الحساب أعلاه يطبّقه. ■

- **النتيجة:** صغرى 0 عند $\pm\sqrt{2}$؛ عظمى 49 عند ± 3.
- **الربط بالذكاء الاصطناعي:** تحليل «مدى الخسارة» على كرة قياسية حول الأوزان: EVT يضمن وجود أسوأ حالة داخل الكرة — أساس تحليل SM. (sharpness)

مثال (7.5-6).

- **المعطيات:** $f(x) = \tan x$ على $[0, \pi]$.
- **المطلوب:** لماذا لا يسري EVT؟
- **الحل:**

١. tan غير متصلة على الفترة كاملة (انقطاع لانهائي عند $\pi/2$).

٢. القيم القصوى غير موجودة (تطير إلى $\pm\infty$). ■

- **النتيجة:** انقطاع واحد يهدم EVT.
- **الربط بالذكاء الاصطناعي:** خسارة متباعدة قرب احتمال صفر لهذا السلوك؛ clipping = «إزالة الانقطاع» بالفرض.

مثال (7.5-7).

- **المعطيات:** معادلة $e^x = 3 - x$.
- **المطلوب:** أثبت حلّاً وحيداً في $(0, 1)$.
- **الحل:**

١. $g(x) = e^x + x - 3$: $g(0) = -2 < 0$، $g(1) = e - 2 \approx 0.718 > 0$.

٢. جذر بالبولزانو.

٣. $g' = e^x + 1 > 0 \Longrightarrow$ تقاطع وحيد. ■

- **النتيجة:** حلّ وحيد في $(0, 1)$.
- **الربط بالذكاء الاصطناعي:** حلّ «شروط التوازن» في تحليل استقرار شبكات المتباينات (GAN) يبدأ بهذا النمط: دالة متصلة وتمييز إشارة عند طرفين.

مثال (7.5-8).

- **المعطيات:** $f(x) = \sin x$ على $[0, 2\pi]$.
- **المطلوب:** طبّق 3.5.7 للقيمة $Y = 0$ (غير القيم الطرفية).
- **الحل:**

١. $f(0) = f(2\pi) = 0$؛ نريد نقطة داخلية c بقيمة 0: $c = \pi$.

٢. فعلاً $f(\pi) = 0 \in (0, 2\pi)$. ■

- **النتيجة:** $c = \pi$ يحقّق القيمة الوسيطة.

- **الربط بالذكاء الاصطناعي:** «العبور الصفري» في الإشارات الدورية هو أساس مصادر العدّ (phase reset) في أدوات تحليل التدرّج الزمني — وتكرار ثبات التوقيت.

مثال (5.7-9).

- **المعطيات:** $f(x) = \frac{1}{x}$ على $[-1, 1], x \neq 0$.
- **المطلوب:** فحص EVT.
- **الحل:**

١. f غير متصلة عند 0 (لانهائية).

٢. لا قيمة عظمى ولا صغرى على الفترة. ■

- **النتيجة:** EVT لا يسري.

- **الربط بالذكاء الاصطناعي:** الخسارة المستوية في «عينات متنافرة» تكشف هذا النمط؛ الاستمرارية شرط الجولة الشاملة لأسوأ الحالات.

مثال (5.7-10).

- **المعطيات:** $f(x) = x^2$ على $(0, 1)$ (فترة مفتوحة).
- **المطلوب:** هل يبلغ القيمة العظمى؟
- **الحل:**

١. القيم تقارب 1 لكن لا تبلغه (1 خارج الفترة).

٢. الصغرى 0 أيضاً غير محقّقة (0 خارج الفترة). ■

- **النتيجة:** لا قيمة قصوى على الفترة المفتوحة.

- **الربط بالذكاء الاصطناعي:** «البحث داخل كرة مفتوحة» قد يفشل في بلوغ أفضل حالة؛ كرة مغلقة (قيد صلب) أساس تحليل الشمول العالمي.

مثال (5.7-11).

- **المعطيات:** $f(x) = x + \sin x$ على $[-2, 2]$.
- **المطلوب:** أثبت أنّ f تبلغ قيمة 1 داخل الفترة.
- **الحل:**

١. $f(-2) \approx -2.909 < 1$.

٢. $f(2) \approx 2.909 > 1$.

٣. البولزانو (بصيغة 3.5.7 على $g = f - 1$) $\Longrightarrow$ نقطة تحقق $f = 1$. ■

- **النتيجة:** توجد نقطة c بـ $f(c) = 1$.

- **الربط بالذكاء الاصطناعي:** التحقّق من «معدّل معقول» بين طرفي مدى التدرّج: القيمة الوسيطة موجودة بالاتصال، والبحث الثنائي يصل إليها بسرعة لوغاريتمية.

مثال (5.7-12).

- **المعطيات:** $f(x) = x^3 - x$ على $[-2, 2]$.
- **المطلوب:** القيم القصوى وطبّق EVT.
- **الحل:**

١. $f' = 3x^2 - 1 = 0 \Rightarrow x = \pm 1/\sqrt{3}$.

٢. محليّاً: قيمة صغرى عند $+1/\sqrt{3}$ بقيمة ≈ -0.385، عظمى ≈ 0.385.

٣. عند الأطراف $f(\pm 2) = \pm 6$ $\Longrightarrow$ العظمى 6 عند $x = 2$. ■

- **النتيجة:** عظمى 6 عند الطرف، صغرى -6 عند -2.

- **الربط بالذكاء الاصطناعي:** «القيم القصوى عند الأطراف» تجسّد لماذا نقيد الأوزان (weight clipping) في WGAN: الأطراف المقيّدة تحكم الحدّ الأعلى للخسارة.

مثال (5.7-13).

- **المعطيات:** $f(x) = x^2 \cos x$ على $[0, 10]$.
- **المطلوب:** أثبت وجود قيمة عظمى (بلا حسابها).
- **الحل:**

١. f متصلة على فترة مغلقة محدودة.

٢. EVT $\Longrightarrow$ قيمة عظمى و صغرى محقّقتان. ■

- **النتيجة:** الوجود مضمون.

- **الربط بالذكاء الاصطناعي:** «حلقة الحماية» الأولى: نثبت الوجود نظرياً قبل محاولة الاستمثال عددياً — القيمة موجودة، وينحصر السؤال في إيجادها.

مثال (7.5-14).

- **المعطيات:** $f(x) = \lfloor x \rfloor$ على $[0, 3]$.
- **المطلوب:** هل يسري EVT؟
- **الحل:**

١. f متصلة على $[0, 3)$... لا؛ غير متصلة عند 1 و 2.

٢. مع ذلك توجد قيم قصوى (0 و 2) — لكن EVT **لا يضمنها.**

٣. درس: صحة الشرط ضروري لكنه ليس دائماً «ضرورياً» — شرط كافٍ. ■

- **النتيجة:** EVT شرط كافٍ لا ضروري.

- **الربط بالذكاء الاصطناعي:** لا تخلط بين «يضمن» و«يمنع»؛ دوال غير سلسة قد تعمل عملياً لكن بلا ضمانات نظرية.

مثال (7.5-15).

- **المعطيات:** $f(x) = 2^x - 4x$.
- **المطلوب:** أثبت وجود جذرين أحدهما في $(0, 1)$ والآخر في $(3, 4)$.
- **الحل:**

١. $f(0) = 1 > 0$، $f(1) = -2 < 0$ $\Longrightarrow$ جذر في $(0, 1)$.

٢. $f(3) = 8 - 12 = -4 < 0$، $f(4) = 16 - 16 = 0$ (جذر طرفي!) — لاحظ أنّ 4 جذر بالضبط.

٣. لجذر داخلي: على $(3, 4)$ النهاية عند الطرف الأيمن تعطي إشارة صفر، فالبولزانو قد لا يضمن داخلية. فعلاً $x = 4$ جذر. ■

- **النتيجة:** جذران: أحدهما في $(0, 1)$ وآخر $x = 4$ (طرفي).

- **الربط بالذكاء الاصطناعي:** «الجذر الطرفي» تحذير في تحليل التقارب: قد تتقارب الخوارزمية إلى حدّ القيد (boundary) لا إلى «الحل الداخلي» الذي نتوقّعه — يجب فحص القيود قبل الاحتفال.

النظرية

dir="ltr"> <div
$\forall \varepsilon > 0\ \exists N \in \mathbb{N} :\ n \geq N \Rightarrow$ ffi $a_n \to L$ **convergence). (Sequence 1.6.7 Definition**
.$|a_n - L| < \varepsilon$
$\forall \varepsilon > 0\ \exists N :\ m, n \geq N \Rightarrow |a_m -$ ffi Cauchy is a_n **sequence). (Cauchy 2.6.7 Definition**
.$a_n| < \varepsilon$
Cauchy. is $a_n \iff$ converges a_n :$\mathbb{R}$ In **.1.6.7 Theorem**

$$a_n \to L \iff \forall \varepsilon > 0\ \exists N :\ n \geq N \Rightarrow |a_n - L| < \varepsilon \tag{6.7}$$

$$a_n \text{ كوشي} \iff \forall \varepsilon > 0\ \exists N :\ m, n \geq N \Rightarrow |a_m - a_n| < \varepsilon \tag{7.7}$$

النظرية 2.6.7 (قواعد الجبر على المتتاليات). إذا كانت $a_n \to L$، $b_n \to M$ فإنّ $a_n \pm b_n \to L \pm M$، $a_n b_n \to LM$، $\frac{a_n}{b_n} \to \frac{L}{M}$ $(M \neq 0)$.

نظرية الضغط (Squeeze)

$$b_n \leq a_n \leq c_n, \quad b_n \to L,\ c_n \to L \implies a_n \to L \tag{8.7}$$

أخطاء شائعة في التقارب المتسلسلي

الخطأ	لماذا خطأ	التصحيح
«تقارب يعني وصولاً»	$1/n \to 0$ دون أن يبلغ 0 أيّ حدّ	التقارب اقتراب لا بلوغ
$\lvert a_{n+1} - a_n\rvert \to 0$ يكفي للتقارب	مثال مضاد: $a_n = \ln n$ (الفروق $\to 0$ والحدّية $\to \infty$)	شرط كوشي أقوى
الحدّية المتزايدة المحدودة قد «تتجاوز» الحدّ	لا، إن كانت متزايدة ومحدودة فتقارب إلى L	$a_n \nearrow L$ مع $a_n \leq L$ دائماً
جمع سلاسل لا نهائية كأعداد منتهية	$\sum 1/n$ يتباعد رغم $1/n \to 0$	السلاسل تحتاج اختبار خاص (فصل لاحق)

أمثلة محلولة على التقارب المتسلسلي (15 مثالاً)

مثال (6.7-1).

- **المعطيات:** $a_n = \dfrac{1}{n}$.
- **المطلوب:** برهن $a_n \to 0$ بتعريف (6.7).
- **الحل:**
١. لكل $\varepsilon > 0$ اختر $N = \lceil 1/\varepsilon \rceil$.
٢. $n \geq N \Rightarrow \frac{1}{n} \leq \frac{1}{N} < \varepsilon$. ■
- **النتيجة:** تقارب إلى 0.
- **الربط بالذكاء الاصطناعي:** $1/n$ rate learning (جدولة عكسية) تلبي شروط تقارب Robbins–Monro — أساس إثبات تقارب SGD الأصلي.

مثال (7.6-2).

- **المعطيات:** $a_n = \dfrac{(-1)^n}{n}$.
- **المطلوب:** النهاية بتعريف ϵ–N.
- **الحل:**

١. $|a_n - 0| = 1/n$.

٢. نفس اختيار N كما في المثال السابق. ■

- **النتيجة:** تقارب إلى 0 (رغم التذبذب في الإشارة).

- **الربط بالذكاء الاصطناعي:** ضجيج SGD المتلاشي المضروب بمعدّل متناقص — التذبذب لا يمنع التقارب إذا كان السِوَار يتلاشى.

مثال (7.6-3).

- **المعطيات:** $a_n = \dfrac{n}{n+1}$.
- **المطلوب:** النهاية.
- **الحل:**

١. $a_n = 1 - \frac{1}{n+1}$.

٢. $|a_n - 1| = \frac{1}{n+1} < \frac{1}{n} \to 0$. ■

- **النتيجة:** الحدّ $= 1$.

- **الربط بالذكاء الاصطناعي:** «نسبة النجاح» على عينة تنمو: يتقارب إلى الحدّ الحقيقي 1 من الأسفل — أساس قانون الأعداد الكبيرة في التقييم.

مثال (7.6-4).

- **المعطيات:** $a_n = \ln n$.
- **المطلوب:** هل $|a_{n+1} - a_n| \to 0$ تكفي للتقارب؟
- **الحل:**

١. $|a_{n+1} - a_n| = \ln \frac{n+1}{n} = \ln(1 + \frac{1}{n}) \to 0$.

٢. لكنّ $a_n \to \infty$ — تتباعد. ■

- **النتيجة:** صفر الفروق لا يكفي؛ شرط كوشي أقوى.

- **الربط بالذكاء الاصطناعي:** تذكير بأنّ «تقلّص الخطوة» وحده لا يضمن توقف الخسارة — يجب فحص التقارب الكلي (شرط كوشي على مسار الأوزان).

مثال (7.6-5).

- **المعطيات:** $a_n = \sqrt{n+1} - \sqrt{n}$.
- **المطلوب:** النهاية (بالمضاعفة بالمرافق).
- **الحل:**

١. $a_n = \dfrac{1}{\sqrt{n+1} + \sqrt{n}}$.

٢. بين $\frac{1}{2\sqrt{n+1}}$ و $\frac{1}{2\sqrt{n}}$؛ كلاهما $\to 0$.

٣. بالضغط: النهاية 0. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** «تحسين هامشي متلاشٍ»: إضافة طبقة جديدة تحسّن الخسارة بمقدار ينكمش كـ $O(1/\sqrt{n})$ — قاعدة التخفيض المتناقص في قوانين التوسّع.

مثال (7.6-6).

- **المعطيات:** $a_n = (1 + \frac{1}{n})^n$.
- **المطلوب:** النهاية.
- **الحل:**

١. من (7.3): الحدّ e.

٢. والمتتالية متزايدة ومحدودة بـ e. ■

- **النتيجة:** $a_n \nearrow e$.

- **الربط بالذكاء الاصطناعي:** «نموّ مركّب بخطوات صغيرة» يساوي النموّ الأُسّي — لماذا نفضّل تحديثات صغيرة متكرّرة على خطوات كبيرة نادرة.

مثال (7.6-7).

- **المعطيات:** $a_n = \dfrac{\sin n}{n}$.
- **المطلوب:** النهاية بالضغط.
- **الحل:**

١. $-\frac{1}{n} \le a_n \le \frac{1}{n}$.

٢. الطرفان $\to 0 \implies$ النهاية 0. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** إشارة اهتمام مقسومة على «درجة الحرارة» المتنامية تتلاشى رغم تذبذب البسط — الضغط يجيب دون حساب البسط.

مثال (7.6-8).

- **المعطيات:** $a_n = \frac{n!}{n^n}$.
- **المطلوب:** النهاية.
- **الحل:**

١. $a_n = \frac{1 \cdot 2 \cdots n}{n \cdot n \cdots n} \le \frac{1}{n} \cdot \frac{2}{n} \cdots$؛ في الواقع $0 \le a_n \le \frac{1}{n} \cdot 1^{n-1}$ لأنّ كل عامل ≤ 1 باستثناء الأول؛ بدقّة: $a_n = \prod_{k=1}^{n} \frac{k}{n} \le \frac{1}{n}$.

٢. بالضغط: $0 \to$. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** «نموّ العوامل» يقابل انفجار الاحتمالات المشتركة في البيايز الساذج عند ضرب مئات الاحتمالات الصغيرة — لهذا نستخدم اللوغاريتمات (log-space).

مثال (7.6-9).

- **المعطيات:** $a_0 = 0$ مع $a_{n+1} = \frac{a_n}{2} + 1$.
- **المطلوب:** النهاية (تكرار نقطة ثابتة).
- **الحل:**

١. إذا تقاربت إلى L فإنّ $L = \frac{L}{2} + 1 \Rightarrow L = 2$.

٢. $|a_{n+1} - 2| = \frac{1}{2}|a_n - 2| \Longrightarrow |a_n - 2| = 2^{-n}|a_0 - 2| \to 0$. ■

- **النتيجة:** تقارب خطّي إلى 2 بعامل $\frac{1}{2}$.

- **الربط بالذكاء الاصطناعي:** هذا «التكرار الانكماشي» نفسه في خوارزميات iteration value للتعلم المعزّز: انكماش $\gamma < 1$ يضمن التقارب الهندسي.

مثال (7.6-10).

- **المعطيات:** $a_n = (-1)^n$.
- **المطلوب:** هل هي كوشي؟
- **الحل:**

١. خذ $\varepsilon = 1$: لأيّ N اختَر $n = N$ (زوجي) و $m = N + 1$ (فردي).

٢. $|a_m - a_n| = 2 > 1 \Longrightarrow$ ليست كوشي. ■

- **النتيجة:** تتباعد (تذبذب ثابت).

- **الربط بالذكاء الاصطناعي:** «الخسارة تقفز بين حوضين» — تقارب المسار يتطلّب تخميداً (momentum) يكسر التذبذب، لا مجرد انتظار.

مثال (7.6-11).

- **المعطيات:** $a_n = \frac{1}{\ln(n+1)}$.
- **المطلوب:** النهاية.
- **الحل:**

١. المقام $\infty \to$ ببطء ($\ln$ لأنّ يهزم بلا شيء... في الواقع $\ln(n+1) \to \infty$).

٢. الحدّية $0 \to \frac{1}{\ln(n+1)} > 0$. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** معدّلات تعلّم لوغاريتمية البطء تنمو نطاقها ببطء؛ التبريد المقابل بطيء جداً — الشهرة: «لوغاريتم يهزم القوة الخطية».

مثال (7.6-12).

- **المعطيات:** $a_n = \frac{n^2}{2^n}$.
- **المطلوب:** النهاية (الأسّي يهزم كثير الحدود).
- **الحل:**

١. $a_{n+1}/a_n = \frac{(n+1)^2}{2n^2} \to \frac{1}{2} < 1$.

٢. من حدّ معيّن البسط يتناقص هندسياً $\Longrightarrow a_n \to 0$. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** «الأسّي يهزم كثير الحدود» يبرّر تفضيل الدوالّ الأسّية (softmax) في بناء التوزيعات: ذيلها يخمد أي نموّ كثيري.

مثال (7.6-13).

- **المعطيات:** $a_n = \frac{n!}{n^n e^{-n}\sqrt{2\pi n}}$ (نسبة ستيرلنغ).
- **المطلوب:** النهاية.
- **الحل:**

١. صيغة ستيرلنغ: $n! \approx \sqrt{2\pi n}\,(n/e)^n\, e^{\theta_n/12n}$.

٢. النسبة $\to e^0 = 1$. ■

- **النتيجة:** 1 — التقارب إلى ستيرلنغ.

- **الربط بالذكاء الاصطناعي:** ستيرلنغ يقدّر لوغاريتمات التوافيق في انتروبيا التصنيفات الكبيرة (مفردات ضخمة) — تقريب أساسي في فصل الإنتروبيا.

مثال (7.6-14).

- **المعطيات:** $a_0 = 1$، $a_{n+1} = \sqrt{2 + a_n}$.
- **المطلوب:** النهاية.
- **الحل:**

١. حدّية: إنّ $a_n \leq 2$ (بالاستقراء) والمتتالية متزايدة.

٢. متزايدة ومحدودة $\Longrightarrow$ تقارب (نظرية 3.6.7: الحدّية المتزايدة المحدودة تقارب).

٣. الحدّ $L = \sqrt{2 + L} \Rightarrow L^2 - L - 2 = 0 \Rightarrow L = 2$. ■

- **النتيجة:** تقارب إلى 2.

- **الربط بالذكاء الاصطناعي:** نفس نمط «التكرار الانكماشي نحو نقطة ثابتة» في حلّ Bellman في التعلم المعزّز — انكماش يضمن التفرد والتقارب.

مثال (7.6-15).

- **المعطيات:** $a_n = \sum_{k=1}^{n} \frac{1}{k}$ (المتسلسلة التوافقية).
- **المطلوب:** هل هي كوشي؟
- **الحل:**

١. $S_{2n} - S_n = \sum_{k=n+1}^{2n} \frac{1}{k} \geq n \cdot \frac{1}{2n} = \frac{1}{2}$.

٢. لكل N اختيار $n = N$ يعطي فرقاً $\geq \frac{1}{2} \Longrightarrow$ ليست كوشي (اختر $\varepsilon = \frac{1}{3}$). ■

- **النتيجة:** التباعد — رغم $1/k \to 0$.

- **الربط بالذكاء الاصطناعي:** تحذير شامل: «حدود صغيرة لا تعني مجموعاً منتهياً» — مسألة جمع التدرّجات الصغيرة عبر حقب لا نهائية في التحليلات النظرية؛ دائماً قارن بمقياس كوشي.

النظرية

dir="ltr"> <div

Pointwise 1.7.7 Definition (ffi D on pointwise $f_n \to f$ convergence). $\forall x \in D$: $f_n(x) \to f(x)$.

Unfiorm 2.7.7 Definition (ffi D on unfiormly $f_n \to f$ convergence).

$$\forall \varepsilon > 0 \; \exists N : \; n \geq N \Rightarrow \sup_{x \in D} |f_n(x) - f(x)| < \varepsilon.$$

$$f_n \rightrightarrows f \iff \varepsilon_n := \sup_{x \in D} |f_n(x) - f(x)| \to 0 \tag{9.7}$$

النظرية 1.7.7 (حفظ الاتصال). إذا كانت كل f_n متصلة على D و $f_n \rightrightarrows f$ فإنّ f متصلة على D.

النظرية 2.7.7 (تبديل النهاية والتكامل). على فترة محدودة $[a,b]$: التقارب الموحّد يسمح بـ

$$\lim_{n\to\infty} \int_a^b f_n = \int_a^b \lim_{n\to\infty} f_n. \tag{10.7}$$

المثال المضاد الشهير

$$f_n(x) = x^n \text{ على } [0,1]: \quad f_n(x) \to \begin{cases} 0 & x < 1 \\ 1 & x = 1 \end{cases} \tag{11.7}$$

النهاية f **غير متصلة** رغم أنّ كل f_n متصلة — لأنّ التقارب نقطيّ وليس موحّداً: $\sup_{[0,1]} |f_n - f| = 1$ لكل n.

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«النقطي كافٍ لتبديل النهاية مع التكامل»	المثال (11.7) يهدمه	موحّد (أو شروط مسيطرة: التقارب المسيطر)
«sup صعب، سأفحص نقطة واحدة»	النقطي يقيس نقاطاً منفردة	الموحّد يقيس «أسوأ نقطة» دفعة واحدة
«المشتقّ يتقارب إذا تقاربت الدوالّ»	يحتاج تقارب المشتقّات نفسها + نقطة	شرط إضافي
الظنّ أنّ التوحيد ينجح على مجال غير محدود تلقائياً	$e^{-x/n}$ على $[0,\infty)$: $\sup = 1$ لا يتلاشى	افحص sup على المجال كله

أمثلة محلولة على التقارب الوظيفي (15 مثالاً)

مثال (7.7-1).

- **المعطيات:** $f_n(x) = x/n$ على $[0,10]$.
- **المطلوب:** أثبت التقارب الموحّد إلى 0.
- **الحل:**

١. $\sup_{[0,10]} |x/n| = 10/n \to 0$.

٢. بالتعريف (9.7) $\Rightarrow$ موحّد. ■

- **النتيجة:** موحّد إلى 0.
- **الربط بالذكاء الاصطناعي:** «تقارب أسوأ نقطة» هو مقياس تحمّل الشبكة عبر المدخلات؛ إثبات موحّد يعطي ضمانة لكل المدخلات دفعة واحدة — أهمّ بكثير من ضمانات النقطة.

مثال (7.7-2).

- **المعطيات:** $f_n(x) = x^n$ على $[0,1]$.
- **المطلوب:** الفحص النقطي والموحّد.
- **الحل:**

١. نقطياً: f كما في (7.11) — غير متصلة.

٢. $\sup|f_n - f| = 1$ لكل n (قرب $x \to 1^-$).

٣. لا تقارب موحّد. ■

- **النتيجة:** نقطي فقط.

• **الربط بالذكاء الاصطناعي:** هذا نمط «الجبل يزحف نحو الحافة»: تقارب جيد في الداخل وتفشّل عند الحافة — نظير تدهور أداء شبكة عند المدخلات الشاذة (out-of-distribution).

مثال (7.7-3).

- **المعطيات:** $f_n(x) = \frac{\sin(nx)}{n}$ على $\mathbb{R}$.
- **المطلوب:** الموحّد؟ وهل تُحفظ قابلية الاشتقاق للنهاية؟
- **الحل:**

١. $\sup|f_n| \le \frac{1}{n} \to 0 \implies$ موحّد إلى 0.

٢. لكنّ $f_n' = \cos(nx)$ لا تقارب نقطياً إلى 0 (تتذبذب).

٣. النهاية ثابتة قابلة للاشتقاق، لكن «تقارب الدوال لا يورّث تقارب المشتقّات». ■

- **النتيجة:** موحّد إلى 0؛ المشتقّات لا تتقارب.

• **الربط بالذكاء الاصطناعي:** الخسارة قد تتقارب بمظهر جيد بينما التدرّجات تتذبذب بعنف — مراقبة التدرّج ضرورية لا الخسارة وحدها.

مثال (7.7-4).

- **المعطيات:** $f_n(x) = \frac{x}{1+n^2x^2}$ على $\mathbb{R}$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: عند $x \neq 0$ المقام يهزم $\Longrightarrow$ 0؛ عند $x = 0$ القيمة 0. النهاية $f \equiv 0$ متصلة.

٢. أقصى $|f_n|$ عند $x = \frac{1}{n}$: القيمة $\frac{1}{2n} \to 0$.

٣. موحّد. ■

- **النتيجة:** موحّد إلى 0.

- **الربط بالذكاء الاصطناعي:** «ذروة متنقلة متناقصة» — قمم الاهتمام في الشبكات قد تتحرك لكنّ ارتفاعها يتلاشى؛ المقياس الموحّد يلتقط ذلك.

مثال (7.7-5).

- **المعطيات:** $f_n(x) = \frac{nx}{1+n^2x^2}$ على $\mathbb{R}$.
- **المطلوب:** قارن بالمثال السابق.
- **الحل:**

١. نقطياً: $0 \to$ لكل x (نفس الحساب).

٢. لكنّ الذروة عند $x = \frac{1}{n}$ بقيمة $\frac{1}{2}$ — لا تتلاشى.

٣. $\sup = \frac{1}{2} \Longrightarrow$ لا موحّد. ■

- **النتيجة:** نقطي فقط.

- **الربط بالذكاء الاصطناعي:** مضاد حاسم: تضخيم البسط (عمق أكبر) يخلق «شوكة» متحركة لا تتلاشى رغم تقارب كل نقطة — استقرار تدريجي زائف.

مثال (7.7-6).

- **المعطيات:** $f_n(x) = x^n(1-x)$ على $[0,1]$.
- **المطلوب:** الموحّد؟
- **الحل:**

١. نقطياً $0 \to$ (بما فيها عند 1).

٢. الذروة عند $x = \frac{n}{n+1}$ بقيمة $\frac{1}{n+1}\left(\frac{n}{n+1}\right)^n \approx \frac{e^{-1}}{n} \to 0$.

٣. موحّد. ■

- **النتيجة:** موحّد إلى 0.

- **الربط بالذكاء الاصطناعي:** «عامل التخميد» $(1-x)$ قرب الحافة أنقذ التوحيد — إمكانية إصلاح التقارب عند الحواف بعامل يُطفئها (قناع حافة).

مثال (7.7-7).

- **المعطيات:** $f_n(x) = \frac{1}{1+e^{-nx}}$ (sigmoid حادّة) على $\mathbb{R}$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: $x > 0 \to 1$، $x < 0 \to 0$، $x = 0 \to \frac{1}{2}$.

٢. النهاية دالة عتبة غير متصلة $\Longrightarrow$ لا موحّد (بحفظ الاتصال 1.7.7).

٣. $\sup = \frac{1}{2}$ عند $x = 0$. ■

- **النتيجة:** نقطي فقط؛ الحدّ هو الخطوة الصلبة.

- **الربط بالذكاء الاصطناعي:** «حدّ درجة الحرارة»: softmax بدرجة حرارة $0 \to$ يصير argmax صلباً؛ الاتصال يُفقد عند الحدّ — خطر في التقطير (distillation) عند درجات حرارة صغيرة جداً.

مثال (8.7-7).

- **المعطيات:** $f_n(x) = \min(1,\, n\,\mathrm{ReLU}(x))$ على $\mathbb{R}$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: $x > 0 \to 1$، $x \le 0 \to 0$ (خطوة صلبة).

٢. $\sup = \frac{1}{2}$ عند $x = \frac{1}{2n}$.

٣. لا موحّد. ■

- **النتيجة:** نقطي فقط.

- **الربط بالذكاء الاصطناعي:** Straight-Through Estimator» يقارب المؤشر الصلب بدوال ناعمة متزايدة الحدة؛ هذا المثال يوضّح لماذا يجب رفع الحدة تدريجياً (annealing) لا فجأة.

مثال (9.7-7).

- **المعطيات:** $f_n(x) = \sum_{k=1}^{n} \frac{x^k}{k!}$ على $[-R, R]$ لأيّ R منتهٍ.
- **المطلوب:** الموحّد إلى e^x؟
- **الحل:**

١. الباقي $|e^x - f_n(x)| \le \sum_{k>n} \frac{R^k}{k!} \to 0$ (مستقل عن x).

٢. موحّد على $[-R, R]$ لكل R. ■

- **النتيجة:** موحّد محلياً (locally unfiorm).

- **الربط بالذكاء الاصطناعي:** هذا «التقارب المحلي الموحّد» يبرّر تبديل النهايات في اشتقاق سلاسل دوال التنشيط، ولهذا تعمل التنفيذات المقطّعة (truncated series) بشكل موثوق على نطاق محدود.

مثال (7.7-10).

- **المعطيات:** $f_n(x) = e^{-nx}$ على $[0, 1]$.

- **المطلوب:** النقطي والموحّد.

- **الحل:**

١. نقطياً: $x > 0 \to 0$، $x = 0 \to 1$. النهاية متقطعة.

٢. $\sup = 1 \implies$ لا موحّد. ■

- **النتيجة:** نقطي فقط.

- **الربط بالذكاء الاصطناعي:** «تلاشي ذاكرة» في RNN: e^{-nx} يفقد كل المحتوى في كل نقطة عدا نقطة الصفر — التذكّر الطويل يحتاج آليات بوّابية (LSTM) لا الأسّيات وحدها.

مثال (7.7-11).

- **المعطيات:** $f_n(x) = \frac{x^n}{n}$ على $[0, 1]$.

- **المطلوب:** الموحّد؟

- **الحل:**

١. $\sup |f_n| \le \frac{1}{n} \to 0$.

٢. موحّد إلى 0. ■

- **النتيجة:** موحّد.

- **الربط بالذكاء الاصطناعي:** قسماً بـ n (الاستقرار الزمني) «يهدّئ» جبل x^n — تسوية النواتج بطول المسار تحوّل التقارب النقطي إلى موحّد.

مثال (7.7-12).

- **المعطيات:** $f_n(x) = \sin\left(x + \frac{1}{n}\right)$ على $\mathbb{R}$.
- **المطلوب:** الموحّد إلى $\sin x$؟
- **الحل:**

١. $|f_n - \sin x| \le \frac{1}{n}$ (بالتقريب: $|\sin u - \sin v| \le |u - v|$).

٢. $\sup \le \frac{1}{n} \to 0 \implies$ موحّد. ■

- **النتيجة:** موحّد.

- **الربط بالذكاء الاصطناعي:** إزاحة طور صغيرة موحّدة التأثير — «الإزاحة الصغيرة على كل الرؤوس» في الانتباه لا تخرّب الاتصال، مضاد للفكر الشائع بأنّ أي إزاحة تكسر الاستقرار.

مثال (7.7-13).

- **المعطيات:** $f_n(x) = n\,x\,e^{-nx^2}$ على $[0, 1]$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: $x > 0$: الأسّي يهزم $\implies 0$؛ $x = 0$: 0.

٢. الذروة عند $x = \frac{1}{\sqrt{2n}}$ بقيمة $\sqrt{\frac{n}{2}e^{-1/2}} \to \infty$.

٣. لا موحّد (بل قيم متفجّرة). ■

- **النتيجة:** نقطي فقط.

- **الربط بالذكاء الاصطناعي:** «شوكة منفلتة»: عامل مبالغ في التضخيم n يخلق قمماً غير محدودة — تحذير من معاملات قياس تنمو مع التدريب دون تنظيم.

مثال (7.7-14).

- **المعطيات:** $f_n(x) = \frac{\cos(nx)}{1+n^2x^2}$ على $[0, \pi]$.
- **المطلوب:** الموحّد؟
- **الحل:**

١. $|f_n| \le \frac{1}{1+n^2x^2} \le \frac{1}{1+n^2a^2}$ على $[a, \pi]$؛ وقرب الصفر قيمة $f_n(0) = 1$!

٢. $f_n(0) = 1$ لكل n بينما النقطي عند $x > 0$ يعطي $0 \implies$ النهاية متقطعة.

٣. لا موحّد. ■

- **النتيجة:** نقطي فقط؛ الشوكة عند الصفر ثابتة.

- **الربط بالذكاء الاصطناعي:** «قمة الأصل» في دوال النواة (kernel) عند التزامن: اختلاف الطور الصفري يحفظ قيمة عالية عند الصفر — تحذير في تنعيم الإشارات بالالتفاف.

مثال (7.7-15).

- **المعطيات:** $f_n(x) = \arctan(nx)$ على $\mathbb{R}$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: $x > 0 \to \frac{\pi}{2}$؛ $x < 0 \to -\frac{\pi}{2}$؛ $x = 0 \to 0$.

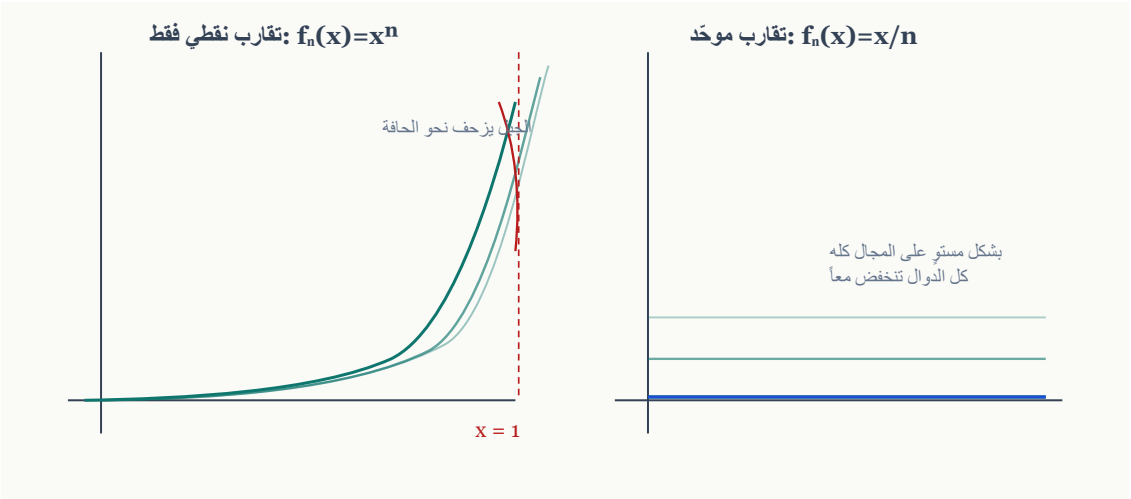
٢. النهاية دالة قفز غير متصلة $\Longrightarrow$ لا موحّد؛ sup يقارب $\frac{\pi}{2}$.

٣. على كل $[a, b]$ بعيداً عن الصفر الموحّد ينجح. ■

- **النتيجة:** نقطي فقط على $\mathbb{R}$؛ موحّد على مجالات مقتطعة.

- **الربط بالذكاء الاصطناعي:** «الاستيفاء بين درجات حرارة»: التقريب النقطي كافٍ بعيداً عن منطقة الانتقال، والمنطقة الحرجة (حدّ القرار) تتطلّب دقّة موحّدة — تركيز التقييم قرب الحدّ.

<figure> الشكل<figcaption> 3.7: يسار — تقارب نقطي فقط: منحنيات x^n «تلتفّ» نحو الحافة والحدّ متقطع.



شكل ٣.٧: *
تقارب نقطي مقابل موحّد

يمين — تقارب موحّد: المنحنيات تنخفض معاً بانتظام على المجال كله.<figcaption/> </figure>

خيط الفصل الواحد

١. δ–ϵ **(2.7)** يمنحنا لغة الدقّة: «خطأ أصغر من ε» — نفس اللغة التي نقيس بها دقّة fp64 مقابل fp16 (فصل 6).

٢. **قوانين النهايات (3.7)** تسمح بتركيب دوالّ من كتل متصلة — نفس تركيب الطبقات في الشبكة.

٣. **الاتصال (4.7)** هو الشرط الذي يحمل انتقالاً صغيراً في المدخل إلى انتقال صغير في الخرج: تعريف **الاستمرارية** بلغة الخسارة.

٤. **نظريات القيم الوسطى (5.7)** تضمن «الوجود»: لكل هدف بين قيمتين يوجد حل — لماذا نثبت الوجود قبل الحساب العددي.

٥. **التقارب المتسلسلي (6.7)** هو لغة خوارزميات التدرّج: $x_k \to x^*$.

٦. **التقارب الموحّد (7.7)** يرفع الضمانة من «لكل نقطة» إلى «لكل النقاط معاً» — الفرق بين أداء شبكة على عيّنة وأدائها المضمون على المجال كله.

جدول الجسور نحو بقية الكتاب

مفهوم هذا الفصل	استخدامه لاحقاً
δ–ϵ	براهين استقرار الخسارة في فصل المتتاليات العليا
الاتصال	شمول العالمية للشبكات (فصل 10)
البولزانو	إثبات وجود حلول لمعادلات التوازن في GAN
شرط كوشي	تقارب SGD/Adam (فصل 40)
التقارب الموحّد	تبديل النهايات في التفاضل الآلي (فصل 36)
$x \log x \to 0$	الإنتروبيا المحدودة (فصل 26)

١. اكتب تعريف δ–ϵ النسبي لـ $\lim_{x\to 1} \frac{1}{x} = 1$ (بتعيين δ بدلالة ε).

٢. أثبت أنّ $\lim_{x\to 0} x \sin \frac{1}{x} = 0$ بتعريف δ–ϵ مباشرة (لا بالحصر).

٣. لكل ε صغير، احسب δ اللازم لـ $f(x) = x^3$ عند $a = 2$.

٤. أثبت أنّ $\lim_{x\to 0} \cos \frac{1}{x}$ لا توجد (باستخدام متتاليتين).

٥. صنّف انقطاعات $f(x) = \frac{x^3 - 8}{x - 2}$ وأصلحها.

٦. صنّف انقطاع $f(x) = e^{1/x}$ عند 0 (ادرس النهايتين الأحاديتين).

٧. أوجد a و b لتكون $f(x) = \begin{cases} ax + b & x < 1 \\ x^2 & x \geq 1 \end{cases}$ متصلة وقابلة للاشتقاق عند 1 (مع استباق الفصل القادم بالميل).

٨. أثبت أنّ كل كثير حدود متصل على $\mathbb{R}$ (من القوانين 2.7).

٩. طبّق البولزانو لإثبات أنّ $x = 2^x$ لها حلّ في $(0, 1)$ ثم في $(0, 2)$: كم حلّاً؟

١٠. أثبت أنّ معادلة $\sin x = x/10$ لها ثلاثة حلول على الأقل في $[-10, 10]$.

١١. ليكن f متصلة على $[0,1]$ بقيم في $[0,1]$. أثبت وجود c بـ $f(c)=c$ (نقطة ثابتة — اسحب $g=f-\mathrm{id}$).

١٢. برهن أنّ $a_n=\frac{3n+1}{n+2}\to 3$ بتعريف (6.7).

١٣. برهن أنّ $a_n=\sqrt[n]{n}\to 1$ (بالتقدير $\ln\sqrt[n]{n}=\frac{\ln n}{n}\to 0$).

١٤. هل $a_n=\cos(n\pi/3)$ كوشي؟ لماذا؟

١٥. برهن أنّ $a_{n+1}=\frac12(a_n+\frac{2}{a_n})$ تقارب إلى $\sqrt2$ لأيّ $a_0>0$ (طريقة هرون).

١٦. افحص التقارب الموحّد لـ $f_n(x)=\frac{n^2x}{1+n^3x^2}$ على $[0,1]$.

١٧. افحص النقطي والموحّد لـ $f_n(x)=\frac{\sin(nx)}{\sqrt n}$ على $\mathbb{R}$، وحدّد هل $\int_0^{\pi}f_n\to 0$.

١٨. اكتب مثالاً مضادّاً: دوال متصلة تتقارب نقطياً إلى حدّ متصل لكن بلا تقارب موحّد (استخدم دوال «سنّ المنشار» المتنقلة).

١٩. أثبت: إذا كانت $f_n\rightrightarrows f$ و $g_n\rightrightarrows g$ على مجموعة محدودة وكانت f,g محدودة، فإنّ $f_ng_n\rightrightarrows fg$.

٢٠. تحدٍّ تركيبي: اجمع بين نظرية البولزانو ومتتالية Bisection لتبرير خوارزمية إيجاد جذر بدقّة ε في $O(\log\frac{b-a}{\varepsilon})$ خطوة، وربطها بحدود الفصل السادس على دقّة fp64.

- **النهاية (1.7):** لعبة δ–ϵ — لكل دقّة خرجٍ ردٌّ بمدخلٍ مناسب.
- **القوانين (2.7):** الجبر على النهايات يصحّ بوجود النهايات؛ حالات عدم التعيين تحتاج أدوات (تحليل، مرافق، لوغاريتم، لاحقاً لوبتال/تايلور).
- **الاتصال (4.7):** $\lim_{x\to a}f(x)=f(a)$ — أربعة أنواع انقطاع، الأول فقط قابل للسدّ.
- **الوجود (5.7):** البولزانو يضمن الجذور؛ EVT يضمن القيم القصوى على المغلقة المحدودة.
- **المتتاليات (6.7)–(8.7):** التقارب والكوشي والضغط — لغة خوارزميات التدرّج.
- **الوظائف (9.7)–(11.7):** النقطي ≠ الموحّد؛ الموحّد هو الذي يحفظ الاتصال ويسمح بتبديل النهايات.

الرمز	المعنى	أين عُرّف
ε,δ	دقّة الخرج ومدى المدخل	(1.7)
$f\in C[a,b]$	متصلة على $[a,b]$	قسم 4.7
$a_n\to L$	تقارب متتالية	(6.7)
كوشي	تساوي الذيل	(7.7)
$f_n\rightrightarrows f$	تقارب موحّد	(9.7)
$\sup_D\lVert f_n-f\rVert$	أسوأ نقطة	(9.7)

١. K. Weierstrass, *Funktionen einer veränderlichen Größe die in Einleitung der Theorie* (محاضرات 1874، صياغة δ–ϵ).

٢. B. Bolzano, *Rein analytischer Beweis des Lehrsatzes...* (1817). — النظرية الوسيطة الأولى بصياغة تحليلية.

٣. W. Rudin, *Principles of Mathematical Analysis*, 3rd ed., McGraw-Hill (الفصل 4: الاستمرارية والاتصال المتسلسل؛ الفصل 7: التقارب الموحّد).

٤. R. Bartle & D. Sherbert, *Introduction to Real Analysis*, 4th ed., Wiley (تعريفات ϵ–δ والتقارب الوظيفي).

٥. H. Robbins & S. Monro, "A Stochastic Approximation Method", *Annals of Mathematical Statistics* 22(3) (1951) — الجدولة a_n المذكورة في الأمثلة.

٦. L. Bottou, F. Curtis & J. Nocedal, "Optimization Methods for Large-Scale Machine Learning", *SIAM Review* 60(2) (2018) — التقارب المتسلسلي لـ SGD.

٧. Y. Abu-Mostafa, M. Magdon-Ismail & H. Lin, *Learning from Data*, AMLBook (2012) — التقارب الموحّد في نظرية التعلم الإحصائي.

٨. N. Higham, *Accuracy and Stability of Numerical Algorithms*, 2nd ed., SIAM (2002) (ربط النهايات بالأخطاء العددية — استمرار للفصل 6).

الاشتقاق وقواعده

الهدف من الفصل

ثاني فصول الجزء الثاني. بنينا في الفصل السابع لغة النهايات والاتصال؛ الآن نصعد درجة واحدة: من «السلوك القرب النقطة» إلى «الميل اللحظي». الاشتقاق هو المحرّك الحقيقي للذكاء الاصطناعي الحديث — كامل التعلّم العميق هو تطبيق متكرر لقاعدة السلسلة التي سنبرهنها هنا.

ثلاثة مواقف من الميدان:

١. **الانتشار العكسي (Backpropagation)** ليس إلا **قاعدة السلسلة** مطبّقة بكفاءة:

$$\frac{\partial L}{\partial W_1} = \frac{\partial L}{\partial a_4} \cdot \frac{\partial a_4}{\partial a_3} \cdots \frac{\partial a_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial W_1}$$

كل محسّن تدرّج (SGD, Adam, RMSProp) يقسم هذا المشتقّ على حجم الدُفعة ويتحرك عكس اتجاهه.

١. **حساب النقاط الحرجة:** أفضل قيم للمعاملات هي حيث $\nabla L = 0$ — نظرياً. لكنّ «النقطة الحرجة» لا تعني حتماً «صغراً»؛ التمييز بين صغرى وكبرى ونقاط سرج يبدأ من المشتقّ الأول والثاني (قسم 6.8).

١. **الدوالّ غير القابلة للاشتقاق في كل مكان:** ReLU و max-pooling و clipping لها زوايا؛ فهم أين يوجد المشتقّ وأين لا يوجد يفسّر لماذا تعمل الـ subgradients ولماذا نستخدم دوالّ ناعمة (GELU, softplus) أحياناً.

خريطة الفصل

القسم	الموضوع	الأداة الأساسية
2.8	تعريف المشتقّ كنهاية	حدّ الفروق
3.8	قواعد الجمع والضرب والقسمة والسلسلة	الجبر التفاضلي
4.8	مشتقّات الدوالّ الأولية	حدّيات مرجعية
5.8	الاشتقاق الضمني والمشتقّات العليا	قاعدة السلسلة العكسية
6.8	نظريات رول والقيمة الوسطى والنقاط الحرجة	رول/MVT
7.8	التجميع: من المشتقّ إلى الانتشار العكسي	تجميع

الحدس

الميل القاطع بين نقطتين a و $a+h$ على منحنى f هو:

$$\text{الميل القاطع} = \frac{f(a+h) - f(a)}{h}$$

كما نُصغّر h يقترب القاطع من **المماس**، وميله يقترب من **المشتقّ**.

التعريف الرسمي

dir="ltr"> <div

Definition 1.2.8 (Derivative). The derivative of f at a is the limit a at dffierentiable

$$f'(a) = \lim_{h \to 0} \frac{f(a+h) - f(a)}{h}$$

Equivalently: (finite). exists

$$f'(a) = \lim_{x \to a} \frac{f(x) - f(a)}{x - a}.$$

$$f'(a) = \lim_{h \to 0} \frac{f(a+h) - f(a)}{h} \tag{1.8}$$

المشتقّان الأحاديان:

$$f'_-(a) = \lim_{h \to 0^-} \frac{f(a+h) - f(a)}{h}, \qquad f'_+(a) = \lim_{h \to 0^+} \frac{f(a+h) - f(a)}{h} \tag{2.8}$$

النظرية 1.2.8 (الاشتقاق $\Longrightarrow$ الاتصال). إذا كانت f قابلة للاشتقاق عند a فإنها متصلة عند a.

البرهان.

$\lim_{x \to a}(f(x) - f(a)) = \lim_{x \to a} \frac{f(x)-f(a)}{x-a} \cdot (x - a) = f'(a) \cdot 0 = 0$. ■

العكس خطأ: $|x|$ متصلة عند 0 وغير قابلة للاشتقاق (الميلان الأحاديان -1 و $+1$).

جدول الرموز

الرمز	الاسم	المعنى
$f'(a)$	مشتقّ لاغرانج	الميل اللحظي عند a
$\frac{df}{dx}\big\|_a$	مشتقّ لايبنيتس	كم يتغيّر f لكل وحدة تغيّر صغيرة في x
h	الزيادة	خطوة صغيرة، $h \to 0$
$f'_{\pm}(a)$	الميلان الأحادية	يمين/يسار النقطة

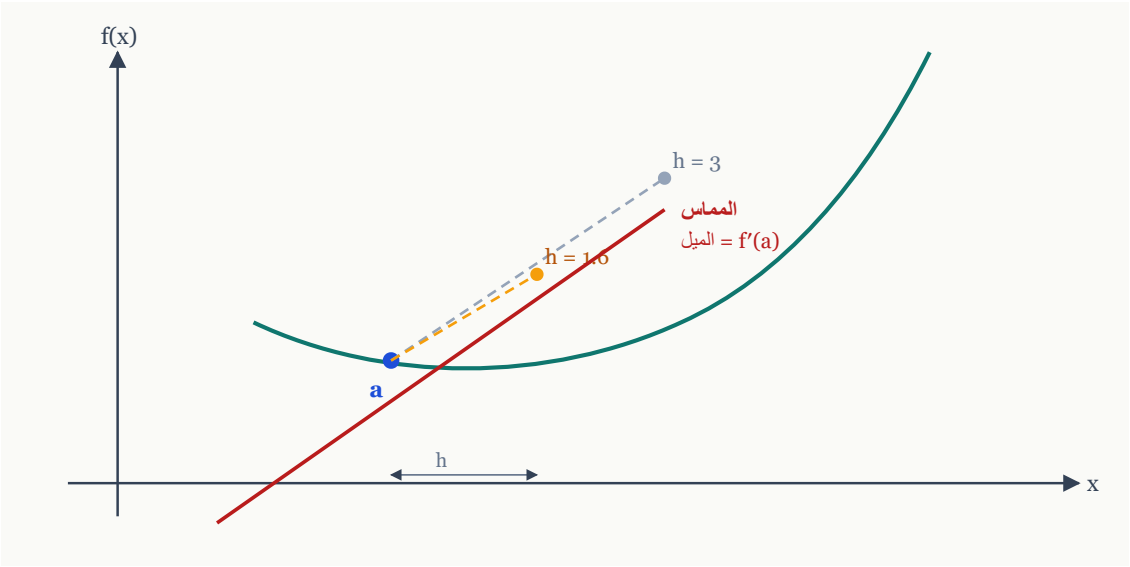
رسم توضيحي

<figure> الشكل<figcaption> 1.8: من القاطع إلى المماس — مع تصغّر h يدور القاطع حول النقطة حتى يستقرّ على المماس، وميله هو $f'(a)$.</figcaption></figure>

أخطاء شائعة في تعريف المشتقّ

الخطأ	لماذا خطأ	التصحيح
«متصلة $\Longrightarrow$ قابلة للاشتقاق»	$\lvert x\rvert$، $\sqrt[3]{x}$، ReLU عند 0	الاتصال ضروري غير كافٍ
«المشتقّ هو الميل بين نقطتين»	ذاك الميل **القاطع**	المشتقّ = نهاية الميول القاطعة
نسيان أنّ المشتقّ دالة	$f'(a)$ قيمة عند نقطة، f' دالة جديدة	المشتقّ له مشتقّ (f'')
حذف الشرط $h \neq 0$ في الحدّ	القسمة على صفر	الحدّ يُدرس عند $h \to 0$ لا $h = 0$

أمثلة محلولة على تعريف المشتقّ (15 مثالاً)



شكل ١٠٨: *
المشتقّ كميل مماس

مثال (1-2.8).

- **المعطيات:** $f(x) = 3x^2 + 1$.
- **المطلوب:** احسب $f'(2)$ من التعريف (1.8).
- **الحل:**

١. $\frac{f(2+h)-f(2)}{h} = \frac{3(2+h)^2+1-13}{h} = \frac{12h+3h^2}{h} = 12 + 3h$.

٢. النهاية عند $h \to 0$: $f'(2) = 12$. ■

- **النتيجة:** 12 — يساوي $6x$ عند $x = 2$.
- **الربط بالذكاء الاصطناعي:** خسارة تربيعية $\|y - \hat{y}\|^2$ لهذا الميل بالضبط؛ لذلك «تدرّجها خطّي في الخطأ» — سلوك الانحدار الخطّي.

مثال (2-2.8).

- **المعطيات:** $f(x) = \frac{1}{x}$.
- **المطلوب:** $f'(a)$ العام من التعريف.
- **الحل:**

١. $\frac{1/(a+h)-1/a}{h} = \frac{a-(a+h)}{h\,a(a+h)} = \frac{-1}{a(a+h)}$.

٢. النهاية: $f'(a) = -\frac{1}{a^2}$ $(a \neq 0)$. ■

- **النتيجة:** $-\frac{1}{a^2}$.

- **الربط بالذكاء الاصطناعي:** تدرّج $1/x$ ينفجر قرب الصفر — السبب العددي نفسه لجمع ϵ في تنظيمات المقام (LayerNorm).

مثال (8.2-3).

- **المعطيات:** $f(x) = \sqrt{x}$.
- **المطلوب:** $f'(a)$ من التعريف عند $a > 0$.
- **الحل:**

١. $\frac{\sqrt{a+h}-\sqrt{a}}{h} = \frac{h}{h(\sqrt{a+h}+\sqrt{a})} = \frac{1}{\sqrt{a+h}+\sqrt{a}}$.

٢. النهاية: $\frac{1}{2\sqrt{a}}$. ■

- **النتيجة:** $f'(a) = \frac{1}{2\sqrt{a}}$.

- **الربط بالذكاء الاصطناعي:** RMSNorm عند القيم الصغيرة: المشتقّ $1/(2\sqrt{a}) \to \infty$ يفسّر الحساسية العددية عند نُرم مُهملة — جمع ϵ يقتطع هذه الشوكة.

مثال (8.2-4).

- **المعطيات:** $f(x) = |x|$.
- **المطلوب:** افحص القابلية للاشتقاق عند 0.
- **الحل:**

١. يميناً: $\frac{h-0}{h} = 1 \to 1$.

٢. يساراً: $\frac{-h-0}{h} = -1 \to -1$.

٣. الميلان مختلفان $\Rightarrow$ لا مشتقّ عند 0 (متصلة رغم ذلك). ■

- **النتيجة:** غير قابلة للاشتقاق عند 0؛ $f' = \operatorname{sgn}(x)$ فيما عدا ذلك.

- **الربط بالذكاء الاصطناعي:** خسارة L1 بالضبط؛ الأطراف تستخدم subgradient (اختيار أي قيمة بين -1 و 1) — عملياً pytorch يعيد sgn.

مثال (8.2-5).

- **المعطيات:** $f(x) = \mathrm{ReLU}(x) = \max(0, x)$.

- **المطلوب:** المشتقّان الأحاديان عند 0 ومناقشة الاختيار.
- **الحل:**

١. $f'_+(0)=1$، $f'_-(0)=0$.

٢. لا مشتقّ عند 0؛ المجموعة الجزئية الجزئية للـ subgradients هي $[0,1]$.

٣. الأطراف الشائعة: 0 (tensorflow) أو 1 (بعض التنفيذات). ■

- **النتيجة:** $f'(x)=\mathbb{1}[x>0]$ عملياً.

- **الربط بالذكاء الاصطناعي:** أيّ قيمة نختار عند الزاوية لا تؤثر نظرياً عند النقاط السرية، لكنها تؤثر عملياً على «وحدات ميتة» (dead ReLU) إذا اخترنا 0 دائماً.

مثال (8.2-6).

- **المعطيات:** $f(x)=x^3$.
- **المطلوب:** $f'(a)$ من التعريف، ولماذا لا توجد «زاوية» عند 0.
- **الحل:**

١. $\frac{(a+h)^3-a^3}{h}=3a^2+3ah+h^2\to 3a^2$.

٢. عند $a=0$: المشتقّ $=0$، والميلان الأحاديان كلاهما 0.

٣. إذن $f'(0)=0$ موجودة — نقطة سلسة (لا زاوية) لكنها نقطة انقلاب (saddle-like). ■

- **النتيجة:** $f'(a)=3a^2$؛ عند 0 مشتقّ صفري مع تغيّر إشارة للمشتقّ.

- **الربط بالذكاء الاصطناعي:** نقاط السرج من هذا النمط (x^3)؛ شهرة خاطئة أنّ $\nabla=0$ يعني قاعاً — لذا نراقب منحنى الخسارة لا قيمة التدرّج وحدها.

مثال (8.2-7).

- **المعطيات:** $f(x)=\sin x$.
- **المطلوب:** $f'(a)$ من التعريف باستخدام الحدّيات المرجعية.
- **الحل:**

١. $\frac{\sin(a+h)-\sin a}{h}=\cos a\cdot\frac{\sin h}{h}-\sin a\cdot\frac{1-\cos h}{h}$.

٢. $\frac{\sin h}{h}\to 1$ و $\frac{1-\cos h}{h}\to 0$.

٣. النتيجة: $f'(a)=\cos a$. ■

- **النتيجة:** $(\sin)'=\cos$.

- **الربط بالذكاء الاصطناعي:** positional encoding الجيبي: تدرّجاته $\sin,\ -\sin$ cos تُغلق دائرة — استقرار الاتجاه عند إزاحات المواضع.

مثال (8-2.8).

- **المعطيات:** $f(x) = e^x$.
- **المطلوب:** $f'(a)$ من التعريف.
- **الحل:**

١. $\frac{e^{a+h}-e^a}{h} = e^a \cdot \frac{e^h-1}{h}$.

٢. الحدّ المرجعي $\frac{e^h-1}{h} \to 1$ (مثال 15-4.7).

٣. النتيجة: $f'(a) = e^a$. ■

- **النتيجة:** e^x دالّة ذاتها مشتقّها — وحيدة بهذه الخاصية (حتى المضاعفات).
- **الربط بالذكاء الاصطناعي:** هذه «الثبات الذاتي» أساس استخدام الأسّ في دوال التنشيط والتفكير في الأنظمة الخطية الزمنية، وأيضاً لماذا softmax مستقر تحليلياً.

مثال (9-2.8).

- **المعطيات:** $f(x) = \ln x$ عند $a > 0$.
- **المطلوب:** $f'(a)$ من التعريف.
- **الحل:**

١. $\frac{\ln(a+h)-\ln a}{h} = \frac{1}{h}\ln\left(1+\frac{h}{a}\right) = \frac{1}{a}\ln\left(1+\frac{h}{a}\right)^{a/h}$.

٢. $\left(1+\frac{h}{a}\right)^{a/h} \to e$ فاللوغاريتم $\to 1$.

٣. النتيجة: $f'(a) = \frac{1}{a}$. ■

- **النتيجة:** $(\ln x)' = \frac{1}{x}$.
- **الربط بالذكاء الاصطناعي:** تدرّج cross-entropy مع softmax يساوي $y - \hat{y}$ — كسور بسيطة بعد اختزال لوغاريتمي، ولهذا يعمل الانتشار العكسي بسلاسة هناك.

مثال (10-2.8).

- **المعطيات:** $f(x) = \begin{cases} x^2 \sin\frac{1}{x} & x \neq 0 \\ 0 & x = 0 \end{cases}$
- **المطلوب:** هل $f'(0)$ موجودة؟
- **الحل:**

١. $\frac{f(h)-f(0)}{h} = h\sin\frac{1}{h}$.

٢. بالضغط: $|h\sin\frac{1}{h}| \le |h| \to 0$.

٣. $f'(0) = 0$ موجودة. لكنّ f' غير متصلة عند 0 (تتذبذب بين ± 1). ■

- **النتيجة:** قابلة للاشتقاق عند 0 لكن المشتقّ غير متصل هناك.

- **الربط بالذكاء الاصطناعي:** «مشتقّ موجود لكن غير متصل» يفسّر تذبذب تدرّجات الشبكات قرب توزيعات المدخلات الحدّية رغم سلاسة الخسارة ظاهرياً.

مثال (8.2-11).

- **المعطيات:** $f(x) = x^{1/3}$.
- **المطلوب:** افحص الاشتقاق عند 0.
- **الحل:**

١. $\frac{h^{1/3}-0}{h} = h^{-2/3} \to +\infty$.

٢. الميل «عمودي» — المماس رأسي.

٣. لا مشتقّ منتهٍ عند 0. ■

- **النتيجة:** مماس عمودي عند 0.

- **الربط بالذكاء الاصطناعي:** خسارة $|w|^{1/2}$ (تنظيم أقوى من L1 لهذا السلوك؛ مشتقّها ينفجر قرب الصفر — لهذا نلجأ لـ proximal methods بدل التدرّج المباشر.

مثال (8.2-12).

- **المعطيات:** $f(x) = \tanh x$.
- **المطلوب:** المشتقّ عند 0 ومناقشة أقصى قيمة.
- **الحل:**

١. $\tanh x = \frac{e^x-e^{-x}}{e^x+e^{-x}}$؛ من الجبر (قسم 4.8): $f'(x) = 1 - \tanh^2 x$.

٢. عند 0: $f'(0) = 1$.

٣. الأقصى عند 0 بالضبط؛ الذيلان $\to 0$. ■

- **النتيجة:** $f'(0) = 1$ وهي القيمة العظمى للمشتقّ.

- **الربط بالذكاء الاصطناعي:** «تلاشي تدرّج»: المشتقّ ≤ 1 ويضمحل أُسّياً في العمق — السبب الأصلي لاختراع LSTM.

مثال (2.8-13).

- **المعطيات:** $f(x) = x^2$.
- **المطلوب:** معامل الاختلاف بين الميل القاطع عند h والمشتقّ عند $a = 1$.
- **الحل:**

١. الميل القاطع $= \frac{(1+h)^2-1}{h} = 2 + h$.

٢. الفرق عن $f'(1) = 2$ هو h بالضبط.

٣. نسبة الخطأ $h/2$: خطأ من الدرجة الأولى. ■

- **النتيجة:** خطأ القاطع $O(h)$.

- **الربط بالذكاء الاصطناعي:** هذا «خطأ الدقة العددية في فرق منته» (فصل 6): حساب التدرّج بالفروق $h = 10^{-8}$ في fp64 يفقد نصف خاناته — والسبب الإلغاء، ولهذا نستخدم backprop التحليلي.

مثال (2.8-14).

- **المعطيات:** $f(x) = \begin{cases} x^2 & x \le 1 \\ 2x - 1 & x > 1 \end{cases}$
- **المطلوب:** هل f قابلة للاشتقاق عند 1؟ (دالة «ملصقة» بسلاسة)
- **الحل:**

١. الاتصال: الطرفان $= 1$ عند $x = 1 \implies$ متصلة.

٢. يساراً: ميل x^2 عند 1 هو 2.

٣. يميناً: ميل $2x - 1$ هو 2 دائماً $\implies$ متساويان $\implies$ **قابلة للاشتقاق** و $f'(1) = 2$. ■

- **النتيجة:** ملصق سلس — قابل للاشتقاق عند نقطة الوصل.

- **الربط بالذكاء الاصطناعي:** هذه تقنية «اللصق السلس» في دوال مثل Huber و softplus: نختار المعاملات ليتساوى القيمة والميل عند نقطة الانتقال.

مثال (2.8-15).

- **المعطيات:** $f(x) = \text{softplus}(x) = \ln(1 + e^x)$.
- **المطلوب:** احسب $f'(x)$ ومناقشة سلوكها عند $\pm\infty$.
- **الحل:**

١. $f'(x) = \frac{e^x}{1+e^x} = \sigma(x)$ (sigmoid).

٢. عند $x \to -\infty$: $f' \to 0$؛ عند $x \to +\infty$: $f' \to 1$.

٣. عند 0: $f'(0) = \frac{1}{2}$ — قيمة ناعمة بدل زاوية ReLU. ■

- **النتيجة:** $(\text{softplus})' = \sigma$ — نسخة ناعمة من ReLU.

- **الربط بالذكاء الاصطناعي:** softplus هو «ReLU القابل للاشتقاق دائماً»؛ يستخدم في توزيعات الانحراف المعياري (VAE) حيث يلزم تدرّج لا صفري في كل مكان.

النظريات

dir="ltr"> <div

(Sum 1.3.8 Theorem $(f \pm g)' = f' \pm g'$ **rule). (Product 2.3.8 Theorem** $(fg)' = f'g + fg'$ **rule). (Quotient 3.3.8 Theorem** $\left(\frac{f}{g}\right)' = \frac{f'g - fg'}{g^2}$ $(g \neq 0)$. **(Chain 4.3.8 Theorem** $(g \circ f)'(x) = g'(f(x)) \cdot f'(x)$ **rule).**

$$(fg)' = f'g + fg' \tag{3.8}$$

$$\left(\frac{f}{g}\right)' = \frac{f'g - fg'}{g^2} \tag{4.8}$$

$$\frac{d}{dx}\, g(f(x)) = g'(f(x)) \cdot f'(x) \tag{5.8}$$

برهان قاعدة السلسلة (بصيغة الاختلافات)

اكتب الاختلافات عند نقطة $u = f(x)$:

$$\Delta u = f'(x)\,\Delta x + \varepsilon_1\,\Delta x, \qquad \Delta g = g'(u)\,\Delta u + \varepsilon_2\,\Delta u,$$

حيث $\varepsilon_i \to 0$ مع $\Delta \to 0$. بالتعويض:

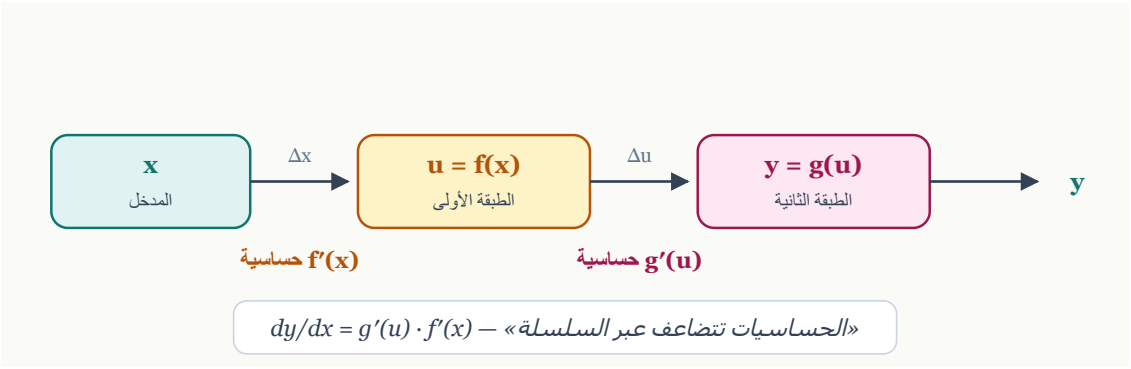
$$\Delta g = g'(u)\,f'(x)\,\Delta x + o(\Delta x) \implies \frac{\Delta g}{\Delta x} \to g'(f(x))\,f'(x). \qquad \blacksquare$$

رسم توضيحي لقاعدة السلسلة

<figure> الشكل<figcaption> 2.8: قاعدة السلسلة نخط أنابيب — التغيير الصغير في x يُضخَّم بمعامل f' ثم بمعامل g'؛ الحاصل الضربي هو حساسية الخرج النهائية. هذا حرفياً «حساب حساسية» في الانتشار العكسي.</figcaption>
</figure>

أخطاء شائعة في قواعد الاشتقاق

الخطأ	لماذا خطأ	التصحيح
$(fg)' = f'g'$	مضاد مثال: $x \cdot x$	قاعدة الضرب (3.8)
$(f \circ g)' = f' \circ g'$	نسيان ضرب مشتقّ الداخل	g' يتضمّن (5.8)
«كل حدّ يشتقّ وحده في حاصل ضرب ثلاثي ثم يُجمع؟»	نعم لكن يجب أن يشتقّ حدّ واحد فقط في كل حدّ مجموع	$(fgh)' = f'gh + fg'h + fgh'$
تطبيق السلسلة على «قوة خارج» دون الداخل	$(\sin^2 x)' \neq 2\sin x$	اكتب $u = \sin x$ ثم u^2
نسيان أنّ ثابتًا مضروباً لا يشتقّ إلى «ثابت»	$(5f)' = 5f'$ لا 5	الثابت المضاعف يخرج كما هو



شكل ٢٠٨: *
قاعدة السلسلة

أمثلة محلولة على قواعد الاشتقاق (15 مثالاً)

مثال (٨.٣-١).

- **المعطيات:** $f(x) = x^2 \sin x$.
- **المطلوب:** $f'(x)$ بقاعدة الضرب.
- **الحل:**

١. $f' = (x^2)' \sin x + x^2 (\sin x)'$.

٢. $f' = 2x \sin x + x^2 \cos x$. ■

- **النتيجة:** $2x \sin x + x^2 \cos x$.

- **الربط بالذكاء الاصطناعي:** نواتج مثل $x^2 \sin x$ تظهر في تفاعل المدخلات مع الترميز الموضعي؛ التدرّج يُفكّك إلى مساهمتين منفصلتين — فكرة «فصل المسارات» في backprop.

مثال (٨.٣-٢).

- **المعطيات:** $f(x) = \dfrac{x}{x^2 + 1}$.
- **المطلوب:** $f'(x)$ بقاعدة القسمة.
- **الحل:**

١. $f' = \dfrac{1 \cdot (x^2 + 1) - x \cdot 2x}{(x^2 + 1)^2}$.

٢. $f' = \dfrac{1 - x^2}{(x^2 + 1)^2}$. ■

- **النتيجة:** $\frac{1-x^2}{(x^2+1)^2}$؛ صفر عند $x = \pm 1$.

- **الربط بالذكاء الاصطناعي:** «بوّابات نافعة» بهذا الشكل الكسوري تتحكم بمرور الإشارة في LSTM؛ صفر المشتقّ يحدّد ذروة المرور.

مثال (3-3.8).

- **المعطيات:** $f(x) = \sin(3x^2)$.
- **المطلوب:** $f'(x)$ بقاعدة السلسلة.
- **الحل:**

١. خارجي $\sin u$، داخلي $u = 3x^2$.

٢. $f' = \cos(3x^2) \cdot 6x$. ■

- **النتيجة:** $6x\cos(3x^2)$.

- **الربط بالذكاء الاصطناعي:** كل معامل متعدّد $(3x^2)$ يخرج كعامل قياس في التدرّج — «تضخيم» داخل الطبقة.

مثال (4-3.8).

- **المعطيات:** $f(x) = e^{-x^2/2}$ (نواة غاوسية).
- **المطلوب:** $f'(x)$.
- **الحل:**

١. خارجي e^u، داخلي $u = -x^2/2$، $u' = -x$.

٢. $f' = e^{-x^2/2} \cdot (-x) = -x\,e^{-x^2/2}$. ■

- **النتيجة:** $-xe^{-x^2/2}$.

- **الربط بالذكاء الاصطناعي:** تدرّج النواة الغاوسية في SVM و attention المبني على المسافة؛ إشارته سالبة للجانب الموجب — «انجذاب» نحو المركز.

مثال (5-3.8).

- **المعطيات:** $f(x) = \sigma(g(x))$ حيث σ الدالة اللوجستية.
- **المطلوب:** برهن $(\sigma \circ g)' = \sigma(g)(1-\sigma(g))\,g'$.
- **الحل:**

١. $(\sigma \circ g)' = \sigma'(g)\,g'$.

٢. $\sigma'(u) = \sigma(u)(1-\sigma(u))$ (مثال 4-4.8).

٣. بالتعويض تنتهي. ■

- **النتيجة:** الصيغة المركّبة السهلة.

- **الربط بالذكاء الاصطناعي:** هذه الصيغة هي «سطر واحد» في backprop عبر طبقة sigmoid: التدرّج يمر مضروباً بـ $\hat{y}(1-\hat{y})$.

مثال (3-8.6).

- **المعطيات:** $f(x) = (2x+1)^5$.
- **المطلوب:** $f'(x)$ بطريقتين (فكّ ثم سلسلة).
- **الحل:**

١. سلسلة: $5(2x+1)^4 \cdot 2 = 10(2x+1)^4$.

٢. فكّ: $f = 32x^5+80x^4+80x^3+40x^2+10x+1$، المشتقّ $= 160x^4+320x^3+240x^2+80x+10$.

٣. مساواة الطريقتين بالتحقق: $10(2x+1)^4$ يتوسع لنفس الحدود. ■

- **النتيجة:** $10(2x+1)^4$ — السلسلة توفّر الجبر.

- **الربط بالذكاء الاصطناعي:** فكّ الأُسّ الخام يقابل «توسيع شبكة عميقة إلى شبكة عريضة»: الجبر ينفجر، السلسلة تبقى خطوات قليلة — لهذا backprop عملي.

مثال (3-8.7).

- **المعطيات:** $f(x) = x^2 e^{3x}$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. ضرب + سلسلة: $f' = 2xe^{3x} + x^2 \cdot 3e^{3x}$.

٢. تجميع: $f' = xe^{3x}(2+3x)$. ■

- **النتيجة:** $xe^{3x}(2+3x)$.

- **الربط بالذكاء الاصطناعي:** نواتج كثيرة حدود مع أسّي تصف قوانين التوسّع؛ تحليل الصفر يحدّد «الطول الأمثل» للسياق.

مثال (3-8.8).

- **المعطيات:** $f(x) = \dfrac{\sin x}{x}$ عند $x \neq 0$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. $f' = \dfrac{x\cos x - \sin x}{x^2}$. ■

- **النتيجة:** $\frac{x\cos x - \sin x}{x^2}$.
- **الربط بالذكاء الاصطناعي:** التدرّج الأول لـ sinc، عند الصفر يحتاج توسّع تايلور ($f'(0) = 0$) — نفس أسلوب «التعويض الحدّي» في تنفيذ دوال خاصة.

مثال (8.3-9).

- **المعطيات:** $f(x) = \ln(1 + e^x)$ (softplus) — مشتقّه مباشرة.
- **المطلوب:** $f'(x)$ بقاعدة السلسلة.
- **الحل:**

١. خارجي $\ln u$، داخلي $u = 1 + e^x$.

٢. $f' = \frac{e^x}{1+e^x} = \sigma(x)$. ■

- **النتيجة:** $f' = \sigma$ — أجمل زوج في التفاضل.
- **الربط بالذكاء الاصطناعي:** backprop عبر softplus يعطي sigmoid مجاناً؛ يستخدم في مخرجات «الانحراف المعياري» في VAE.

مثال (8.3-10).

- **المعطيات:** $f(x) = (x^2 + 1)^{10}$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. سلسلة: $10(x^2 + 1)^9 \cdot 2x$.

٢. $f' = 20x(x^2 + 1)^9$. ■

- **النتيجة:** $20x(x^2 + 1)^9$.
- **الربط بالذكاء الاصطناعي:** «قوة على مجموع مربعات» هي الشكل العام لمشتقّ $\|v\|^{2p}$ في تنظيم الأوزان؛ العامل $2x$ هو «اتجاه الإصلاح».

مثال (8.3-11).

- **المعطيات:** $f(x) = \sqrt{x^2+4}\cdot e^{-x}$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. ضرب: $u = \sqrt{x^2+4}$ $\left(u' = \frac{x}{\sqrt{x^2+4}}\right)$، $v = e^{-x}$ $(v' = -e^{-x})$.

٢. $f' = \frac{x}{\sqrt{x^2+4}}e^{-x} - \sqrt{x^2+4}\,e^{-x} = e^{-x}\left(\frac{x}{\sqrt{x^2+4}} - \sqrt{x^2+4}\right)$.

٣. اختزال: $f' = \frac{e^{-x}(x-(x^2+4))}{\sqrt{x^2+4}} = \frac{-e^{-x}(x^2-x+4)}{\sqrt{x^2+4}}$. ■

- **النتيجة:** $\frac{-e^{-x}(x^2-x+4)}{\sqrt{x^2+4}}$ — دائماً سالبة $(\Delta = 1-16<0)$.

- **الربط بالذكاء الاصطناعي:** «دالة متناقصة دائماً» — نمط مفيد في إثبات عدم وجود محليّات في مسارات معيّنة (تقلّص تدريجي للعوامل).

مثال (8.3-12).

- **المعطيات:** $f(x) = \sin(\cos(\tan x))$.
- **المطلوب:** $f'(x)$ بثلاث طبقات سلسلة.
- **الحل:**

١. خارجي→داخلي→أعمق: $\sin \to \cos \to \tan$.

٢. $f' = \cos(\cos(\tan x))\cdot(-\sin(\tan x))\cdot \sec^2 x$.

٣. $f' = -\sec^2 x\,\sin(\tan x)\cos(\cos(\tan x))$. ■

- **النتيجة:** حاصل ضرب ثلاث حساسيات.

- **الربط بالذكاء الاصطناعي:** «عمق ثلاث طبقات» — لو انهارت إحدى الحساسيات إلى صفر انقطع التدفق كله (vanishing gradient)؛ الشوكة عند $\tan x \to \infty$ هي الانفجار.

مثال (8.3-13).

- **المعطيات:** $f(x) = x^x$ $(x>0)$.
- **المطلوب:** $f'(x)$ بأسّ متغيّر.
- **الحل:**

١. اكتب $f = e^{x \ln x}$.

٢. $f' = e^{x \ln x}(\ln x + 1) = x^x(\ln x + 1)$. ■

- **النتيجة:** $x^x(\ln x + 1)$.

- **الربط بالذكاء الاصطناعي:** الأسّيات المتغيّرة تظهر في تقديرات «عدد المسارات» في المزج بين الخبراء (MoE)؛ اللوغاريتم أولاً دائماً قبل الاشتقاق.

مثال (14-3.8).

- **المعطيات:** $f(x) = \dfrac{e^{2x}}{1+e^{2x}}$ (sigmoid بحدين مضاعفين).
- **المطلوب:** $f'(x)$ والتحقق من المساواة لـ $\sigma(2x)$.
- **الحل:**

١. $f' = 2\sigma(2x)(1-\sigma(2x)) \implies f = \sigma(2x)$.

٢. بقاعدة القسمة مباشرة: $\frac{2e^{2x}}{(1+e^{2x})^2} = \frac{2e^{2x}(1+e^{2x}) - e^{2x} \cdot 2e^{2x}}{(1+e^{2x})^2}$ — نفس القيمة. ■

- **النتيجة:** $2\sigma(2x)(1-\sigma(2x))$.

- **الربط بالذكاء الاصطناعي:** «مضاعفة الحدّ» تضاعف المشتقق؛ معايرة درجة حرارة softmax: الحرارة T تقسم الحدّ وتقسم المشتقق أيضاً.

مثال (15-3.8).

- **المعطيات:** $L(W) = \frac{1}{2}\|WX - y\|_2^2$ حيث W مصفوفة، x, y متجهات.
- **المطلوب:** مشتقّ L بالنسبة إلى W (نسخة مصفوفية للسلسلة — تمهيد للفصل متعدد المتغيرات).
- **الحل:**

١. سلسلة: $\nabla_W L = (WX - y) \cdot \frac{\partial (WX-y)}{\partial W}$.

٢. بالتمثيل السطحي للحواف: $\nabla_W L = (WX - y)\, x^\top$. ■

- **النتيجة:** $\nabla_W L = (\hat{y} - y)x^\top$ — «الخطأ مضروباً في المدخل».

- **الربط بالذكاء الاصطناعي:** هذه هي قاعدة التحديث في كل طبقة خطية: $\Delta W \propto (\hat{y} - y)x^\top$ — قاعدة دلتا (delta rule) وهي قلب backprop كله.

الجدول الأساسي

الدالة	المشتقّ	ملاحظة
c (ثابت)	0	
x^n	$n\,x^{n-1}$	لأيّ عدد حقيقي n
e^x	e^x	ذاتية الاشتقاق
a^x	$a^x \ln a$	$= e^{x \ln a}$
$\ln x$	$\dfrac{1}{x}$	$x > 0$
$\log_a x$	$\dfrac{1}{x \ln a}$	
$\sin x$	$\cos x$	
$\cos x$	$-\sin x$	
$\tan x$	$\sec^2 x = \dfrac{1}{\cos^2 x}$	
$\arctan x$	$\dfrac{1}{1+x^2}$	بلا انفجار!
$\arcsin x$	$\dfrac{1}{\sqrt{1-x^2}}$	
$\sigma(x) = \dfrac{1}{1+e^{-x}}$	$\sigma(1-\sigma)$	قلب اللوجستية

برهان موضعي — مشتقّ السيجمويد:

$$\sigma'(x) = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{1}{1+e^{-x}} \cdot \frac{e^{-x}}{1+e^{-x}} = \sigma(x)\,(1-\sigma(x)) \tag{6.8}$$

برهان موضعي — مشتقّ tanh:

$$(\tanh x)' = 1 - \tanh^2 x \tag{7.8}$$

برهان موضعي — مشتقّ arctan:

من $y = \arctan x \Rightarrow x = \tan y$، وبقاعدة السلسلة العكسية:

$$\frac{dy}{dx} = \frac{1}{\sec^2 y} = \frac{1}{1+\tan^2 y} = \frac{1}{1+x^2} \tag{8.8}$$

أخطاء شائعة في مشتقّات الدوالّ الأولية

الخطأ	لماذا خطأ	التصحيح
$(\ln x)' = \ln x$ أو «ثابت»	اللوغاريتم مشتقّه $1/x$	(الجدول)
$(\tan x)' = \sec x$	نسيان التربيع	$\sec^2 x$
$(\cos x)' = \sin x$	نسيان الإشارة	$-\sin x$
$(x^\pi)' = \pi x^\pi$	نسيان خفض الأس	$\pi x^{\pi-1}$
$(a^x)' = x\,a^{x-1}$	خلط قوة بمتغيّر	$a^x \ln a$

أمثلة محلولة على مشتقّات الدوالّ الأولية (15 مثالاً)

مثال (4.8-1).

- **المعطيات:** $f(x) = x^{3/2}$.
- **المطلوب:** $f'(x)$ (أس كسري).
- **الحل:**

١. $f' = \frac{3}{2}x^{1/2}$.

٢. عند $x = 0$: المشتقّ $0 =$ (من اليمين) — سلس. ■

- **النتيجة:** $\frac{3}{2}\sqrt{x}$.

- **الربط بالذكاء الاصطناعي:** لوغاريتم أُسّ كسري في عقوبات «شبه L1.5» بين L1 و L2 — ضبط قابلية الاشتقاق عند الصفر باختيار الأس.

مثال (4.8-2).

- **المعطيات:** $f(x) = 2^x$.
- **المطلوب:** $f'(x)$ وقيمتها عند 0.
- **الحل:**

١. $f' = 2^x \ln 2$.

٢. عند 0: $\ln 2 \approx 0.693$. ■

- **النتيجة:** $2^x \ln 2$.

- **الربط بالذكاء الاصطناعي:** «لماذا الأساس e خاص؟» — مشتقّه 1 عند الصفر، التطبيع بـ ln في انتروبيا يستخدم الأساس الطبيعي لهذا السبب.

مثال (4.8-3).

- **المعطيات:** $f(x) = \ln(2x + 1)$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. سلسلة: $f' = \frac{2}{2x+1}$. ■

- **النتيجة:** $\frac{2}{2x+1}$.

- **الربط بالذكاء الاصطناعي:** «لوغاريتم داخلي متعدد» — تدرّجات عدد المميزات في softmax المساوي: يُحسب بعد اللوغاريتم لتفادي الإلغاء (log-sum-exp، فصل 6).

مثال (4-4.8).

- **المعطيات:** $\sigma(x) = \frac{1}{1+e^{-x}}$.
- **المطلوب:** برهن (6.8) ثم احسب $\sigma'(0)$ والقيمة العظمى للمشتقّ.
- **الحل:**

١. بقاعدة القسمة أو إعادة الكتابة: $\sigma' = \sigma(1-\sigma)$.

٢. عند 0: $\sigma = \frac{1}{2} \Rightarrow \sigma'(0) = \frac{1}{4}$.

٣. القيمة العظمى $\frac{1}{4}$ عند 0 (تفتيش داخلي بسيط). ■

- **النتيجة:** $\sigma'(0) = \frac{1}{4}$، والحد الأقصى للمشتقّ $\frac{1}{4}$.
- **الربط بالذكاء الاصطناعي:** «أقصى تمرير $\frac{1}{4}$ لكل طبقة» sigmoid — ضرب $\frac{1}{4}$ عبر 10 طبقات يعطي 10^{-6}: انهيار التدرّج التاريخي الذي قاد إلى ReLU.

مثال (5-4.8).

- **المعطيات:** $f(x) = \tanh x$.
- **المطلوب:** برهن (7.8) وقارن الحد الأقصى للمشتقّ مع sigmoid.
- **الحل:**

١. $\tanh = \frac{e^x - e^{-x}}{e^x + e^{-x}}$؛ بالقسمة: $f' = 1 - \tanh^2 x$.

٢. الحد الأقصى عند 0: 1.

٣. يقارن بـ sigmoid: أربعة أضعاف (1 مقابل $\frac{1}{4}$). ■

- **النتيجة:** $(\tanh)' = 1 - \tanh^2$؛ الذروة 1.
- **الربط بالذكاء الاصطناعي:** لهذا فضّلت شبكات 1998–2015 الـ tanh على sigmoid في الطبقات الخفية — مرور تدرّج أقوى.

مثال (6-4.8).

- **المعطيات:** $f(x) = \arctan x$.
- **المطلوب:** برهن (8.8) وناقش سلوك الذيل.
- **الحل:**

١. من $x = \tan y$ والسلسلة العكسية: $f' = \frac{1}{1+x^2}$.

٢. الذيل: $f' \approx \frac{1}{x^2}$ — يتلاشى بسرعة.

٣. عند 0: $f' = 1$ أقصى قيمة. ■

- **النتيجة:** $\frac{1}{1+x^2}$.

- **الربط بالذكاء الاصطناعي:** «تحوّل بلا انفجار»: أركتان له مشتقّ محدود دائماً — يستخدم في تدرّج الزوايا وتطبيع الاتجاهات في الأنظمة الجيومكانية.

مثال (8.4-7).

- **المعطيات:** $f(x) = x \ln x$ $(x > 0)$.
- **المطلوب:** $f'(x)$ ونقطة الصفر.
- **الحل:**

١. $f' = \ln x + 1$.

٢. صفر عند $x = e^{-1}$. ■

- **النتيجة:** $\ln x + 1$، صغرى الدالة عند e^{-1}.

- **الربط بالذكاء الاصطناعي:** $p \ln p$ في الإنتروبيا: ميله عند $p = e^{-1}$ يحدّد «أحسّ احتمال فردي» من منظور المساهمة السلبية في الإنتروبيا.

مثال (8.4-8).

- **المعطيات:** $f(x) = e^{-\lambda x}$ $(\lambda > 0)$.
- **المطلوب:** $f'(x)$ وثبات النسبة.
- **الحل:**

١. $f' = -\lambda e^{-\lambda x}$.

٢. النسبة $f'/f = -\lambda$ ثابتة — «تفكك أُسّي بمعدّل ثابت». ■

- **النتيجة:** $-\lambda e^{-\lambda x}$.

- **الربط بالذكاء الاصطناعي:** «تلاشي الذاكرة بمعدّل ثابت» في RNN الأصلية — تحليل أثر الضرب المتكرر بمعامل $\lambda < 1$.

مثال (8.4-9).

- **المعطيات:** $f(x) = \ln|x|$.
- **المطلوب:** $f'(x)$ على المجموعتين $x > 0$ و $x < 0$.
- **الحل:**

١. $x > 0$: $f' = \frac{1}{x}$.

٢. $x < 0$: $f' = \frac{1}{x}$ (بالمعامل $|x| = -x$).

٣. إذن $(\ln|x|)' = \frac{1}{x}$ في كلٍّ من المجالين، بلا تعريف عند 0. ■

- **النتيجة:** $\frac{1}{x}$ على كلا الفرعين.

- **الربط بالذكاء الاصطناعي:** نواة kernel (فصل SVM) بمدخل سلبي محتمل: استخدام $\ln|x|$ بدل $\ln x$ يتجنّب NaN في التنفيذ.

مثال (8.4-10).

- **المعطيات:** $f(x) = \sin^2 x$.
- **المطلوب:** $f'(x)$ بطريقتين.
- **الحل:**

١. سلسلة: $2\sin x \cos x$.

٢. هوية: $\sin^2 x = \frac{1-\cos 2x}{2} \Rightarrow f' = \sin 2x$.

٣. المساواة: $2\sin x\cos x = \sin 2x$. ■

- **النتيجة:** $\sin 2x$.

- **الربط بالذكاء الاصطناعي:** «تبسيط قبل الاشتقاق» يوفّر حساباً — نفس فلسفة الاختزال في backprop قبل الحساب العددي.

مثال (8.4-11).

- **المعطيات:** $f(x) = xe^{-x}$.
- **المطلوب:** $f'(x)$ ونقطة الذروة.
- **الحل:**

١. $f' = e^{-x}(1-x)$.

٢. صفر عند $x = 1$ — ذروة «كثافة بواسون النمطية» عند متوسطها. ■

- **النتيجة:** $e^{-x}(1-x)$، ذروة عند 1.

- **الربط بالذكاء الاصطناعي:** توزيع بواسون/غاما في نمذجة «عدد الصناديق الجديدة»؛ الذروة عند المتوسط تُستخدم في تهيئة عوامل التوزيع.

مثال (8.4-12).

- **المعطيات:** $f(x) = \log_2 x$.
- **المطلوب:** $f'(x)$ وقارن مع $\ln x$.
- **الحل:**

١. $f' = \frac{1}{x \ln 2} \approx \frac{1.443}{x}$.

٢. أكبر من مشتقّ اللوغاريتم الطبيعي بعامل $\frac{1}{\ln 2}$. ■

- **النتيجة:** $\frac{1}{x \ln 2}$.

- **الربط بالذكاء الاصطناعي:** إنتروبيا «بالبت» مقابل «النات» — العامل $\ln 2$ فقط؛ نتائج التدريب لا تتأثر إلا بمقياس التدرّج الأولي.

مثال (8.4-13).

- **المعطيات:** $f(x) = \arcsin x$ على $(-1, 1)$.
- **المطلوب:** $f'(x)$ وسلوكها عند الأطراف.
- **الحل:**

١. من $x = \sin y$: $f' = \frac{1}{\cos y} = \frac{1}{\sqrt{1-x^2}}$.

٢. عند الأطراف $\to \infty$ — انفجار. ■

- **النتيجة:** $\frac{1}{\sqrt{1-x^2}}$.

- **الربط بالذكاء الاصطناعي:** قصّ «المساحات المماسية» عند الأطراف (clipping) مطلوب دائماً؛ تقريب $1 - x^2$ قرب 1 يُفقد الدقّة — استخدم asqrt1px2 عند توفره.

مثال (8.4-14).

- **المعطيات:** $f(x) = \ln(\ln x)$ $(x > 1)$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. سلسلة: $f' = \frac{1}{\ln x} \cdot \frac{1}{x} = \frac{1}{x \ln x}$. ■

- **النتيجة:** $\frac{1}{x \ln x}$.

- **الربط بالذكاء الاصطناعي:** هذا هو «مشتقّ محاسبة الاهتمام على عمق مزدوج» — نمط لوغاريتم-لوغاريتم في قوانين التوسّع (scaling laws) كثيرة الأُسّ.

مثال (15-4.8).

- **المعطيات:** $f(x) = \mathrm{GELU}(x) = x\,\Phi(x)$ مع $\Phi(x) \approx \sigma(1.702x)$ (تقريب sigmoid الشائع).
- **المطلوب:** $f'(x)$ بالتقريب وقارن سلوكها مع ReLU.
- **الحل:**

١. $f' \approx \sigma(1.702x) + x \cdot 1.702\,\sigma(1.702x)(1-\sigma(1.702x))$.

٢. عند $x \to -\infty$: الحدّ الأول $\to 0$ والثاني $\to 0$ (أسّيّاً) — سلس.

٣. عند $x \to +\infty$: $\to 1$ مثل ReLU. ■

- **النتيجة:** نسخة ناعمة تماماً من مشتقّ ReLU.

- **الربط بالذكاء الاصطناعي:** GELU في المحوّلات (transformers) — سلاسة المشتقّ تُلاحظ في ثبات تدرّجات النماذج الضخمة مقارنة بـ ReLU القابل للزوايا.

الاشتقاق الضمني

عندما تربط معادلة $F(x,y) = 0$ بين x و y ضمنياً (بلا حلّ صريح لـ y)، نشتقّ الطرفين بالنسبة إلى x معتبرين $y = y(x)$، ونطبّق السلسلة على كل حدّ فيه y:

$$\frac{d}{dx}F(x,y(x)) = 0 \quad \Longrightarrow \quad \text{حلّ معادلة جبرية لـ } \frac{dy}{dx} \tag{9.8}$$

المشتقّات العليا

$$f''(x) = \frac{d}{dx}f'(x), \qquad f^{(n)}(x) = \frac{d^n}{dx^n}f(x) \tag{10.8}$$

النظرية 1.5.8. $(e^{\lambda x})^{(n)} = \lambda^n e^{\lambda x}$؛ $(\sin x)^{(n)} = \sin\left(x + \frac{n\pi}{2}\right)$.

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اشتقاق y^2 كـ $2y$	نسيان أنّ $y = y(x)$	السلسلة على الدالة الضمنية — $2y\,y'$
نسيان اشتقاق ثابت C في المعادلة الضمنية	يختفي الحدّ	$C' = 0$
f'' يحسب مرة واحدة	الاشتقاق مرتان متتاليتان	ثبّت f' كدالة ثم اشتقّ
الخلط بين $f'' = 0$ و«نقطة انعطاف»	يجب أن يتغيّر إشارة f''	فحص الإشارة حول النقطة

أمثلة محلولة على الاشتقاق الضمني والمشتقّات العليا (15 مثالاً)

مثال (5.8-1).

- **المعطيات:** $x^2 + y^2 = 25$ (دائرة).
- **المطلوب:** $\frac{dy}{dx}$ ضمنياً عند النقطة $(3, 4)$.
- **الحل:**

١. اشتقاق الطرفين: $2x + 2y\,y' = 0$.

٢. $y' = -\frac{x}{y} = -\frac{3}{4}$. ■

- **النتيجة:** $-\frac{3}{4}$ — ميل عمودي على نصف القطر.

- **الربط بالذكاء الاصطناعي:** «قيد دائري» على متجه الأوزان: التدرّج المسموح يقع مماسياً — أساس إسقاط التدرّج (gradient projection) في WGAN.

مثال (5.8-2).

- **المعطيات:** $xy = 1$ (yperbola).
- **المطلوب:** y' ضمنياً وتحقّق بالحلّ الصريح.
- **الحل:**

١. ضمنياً: $y + xy' = 0 \Rightarrow y' = -\frac{y}{x}$.

٢. صراحةً $y = \frac{1}{x}$: $y' = -\frac{1}{x^2}$.

٣. مساواة: $-\frac{1/x}{x} = -\frac{y}{x}$. ■

- **النتيجة:** $y' = -1/x^2$ بطريقتين.

- **الربط بالذكاء الاصطناعي:** «المتتبّع الضمني» مفيد عندما لا يوجد حلّ صريح — نفس مبدأ الاشتقاق الضمني في طبقات deep equilibrium models (DEQ).

مثال (5.8-3).

- **المعطيات:** $e^{xy} = x + y$.
- **المطلوب:** y' عند النقطة $(0, 1)$.
- **الحل:**

١. اشتقاق: $e^{xy}(y + xy') = 1 + y'$.

٢. عند $(0,1)$: $e^{0}(1+0) = 1 + y' \Rightarrow y' = 0$. ■

- **النتيجة:** $y' = 0$ — نقطة مماس أفقي.

- **الربط بالذكاء الاصطناعي:** نقاط «تدرّج صفري» على منحنيات القيد — لحظة توقف صامتة للمحسّن إذا اعتمدنا الميل وحده.

مثال (8.5-4).

- **المعطيات:** $x^3 + y^3 = 6xy$ (فوليوم الحلزون).

- **المطلوب:** y' عام.

- **الحل:**

١. $3x^2 + 3y^2 y' = 6y + 6xy'$.

٢. تجميع: $y'(3y^2 - 6x) = 6y - 3x^2$.

٣. $y' = \frac{2y - x^2}{y^2 - 2x}$. ■

- **النتيجة:** $\frac{2y-x^2}{y^2-2x}$ (عندما يكون المقام غير صفري).

- **الربط بالذكاء الاصطناعي:** «حساسية متغيّر ضمني» في الطبقات المفاهيمية (concept layers): النسبة بين تدرّجين جزئيين تحلّ محلّ الحلّ الصريح.

مثال (8.5-5).

- **المعطيات:** $\sin(xy) = x$.

- **المطلوب:** y'.

- **الحل:**

١. $\cos(xy)(y + xy') = 1$.

٢. $y' \, x\cos(xy) = 1 - y\cos(xy)$.

٣. $y' = \frac{1 - y\cos(xy)}{x\cos(xy)}$. ■

- **النتيجة:** كما أعلاه.

- **الربط بالذكاء الاصطناعي:** دوالّ دورية ضمنية تصف «دورات» في مسارات GAN؛ الميل الضمني يقدّر حساسية الطور.

مثال (5.8-6).

- **المعطيات:** $f(x) = x^2 e^x$.
- **المطلوب:** f'' وعند أي نقطة $f'' = 0$.
- **الحل:**

١. $f' = e^x(x^2 + 2x)$.

٢. $f'' = e^x(x^2 + 4x + 2)$.

٣. صفر عند $x = -2 \pm \sqrt{2}$. ■

- **النتيجة:** $e^x(x^2 + 4x + 2)$، جذران للانعطاف.
- **الربط بالذكاء الاصطناعي:** «تقوّس الخسارة» $f'' > 0$ يحدّد منطقة الاكتئاب (قاع محدّب) — شرط ضمان تقارب SGD محلياً بمعدّل تعلّم صغير.

مثال (5.8-7).

- **المعطيات:** $f(x) = \ln x$.
- **المطلوب:** f'' وإشارتها.
- **الحل:**

١. $f' = \frac{1}{x} > 0$، $f'' = -\frac{1}{x^2} < 0$ دائماً.

٢. اللوغاريتم **مقعّر** (concave) في كل مجاله. ■

- **النتيجة:** $-1/x^2$ — مقعّرية كلية.
- **الربط بالذكاء الاصطناعي:** مقعّرية ln تضمن أنّ «الاستفادة الحدّية متناقصة» — أساس برهان إمكانية فريد كلاسيكي، وتحليل عائد زيادة البيانات المتناقص.

مثال (5.8-8).

- **المعطيات:** $f(x) = e^{\lambda x}$.
- **المطلوب:** $f^{(n)}$.
- **الحل:**

١. $f' = \lambda e^{\lambda x}$، $f'' = \lambda^2 e^{\lambda x}$، ...

٢. بالاستقراء: $f^{(n)} = \lambda^n e^{\lambda x}$. ■

- **النتيجة:** $\lambda^n e^{\lambda x}$.
- **الربط بالذكاء الاصطناعي:** «طيف مشتقّات» للأسّي: كل اشتقاق يضاعف λ — في تحليل Adam، n=عدد الحقب يعطي نموّاً هندسياً للإشارات المكوّنة.

مثال (8.5-9).

- **المعطيات:** $f(x) = \sin x$.
- **المطلوب:** $f^{(n)}$ بصيغة مغلقة.
- **الحل:**

١. $f' = \cos x = \sin(x + \frac{\pi}{2})$.

٢. تكراراً: $f^{(n)} = \sin(x + \frac{n\pi}{2})$.

٣. الدورة 4. ■

- **النتيجة:** $\sin(x + \frac{n\pi}{2})$.

- **الربط بالذكاء الاصطناعي:** «دورة مشتقّات» في الترميز الجيبي: تدوير الطور مع كل اشتقاق — يُستخدم في تمييز المسارات الزمنية للإشارات.

مثال (8.5-10).

- **المعطيات:** $f(x) = \frac{1}{1-x}$ على $|x| < 1$.
- **المطلوب:** $f^{(n)}$ وربطها بمتسلسلة هندسية.
- **الحل:**

١. $f' = \frac{1}{(1-x)^2}$، $f'' = \frac{2}{(1-x)^3}$، ...

٢. $f^{(n)} = \frac{n!}{(1-x)^{n+1}}$.

٣. عند $x = 0$: قيمها $n!$ — معاملات المتسلسلة الهندسية. ■

- **النتيجة:** $\frac{n!}{(1-x)^{n+1}}$.

- **الربط بالذكاء الاصطناعي:** معاملات تايلور تساوي المشتقّات على $n!$ — أول برهان «توسيع دالة إلى سلسلة» يستخدمه فصل تايلور القادم لتفسير GELU.

مثال (8.5-11).

- **المعطيات:** $x^2 + y^2 = 1$.
- **المطلوب:** y'' ضمنياً.
- **الحل:**

١. من $2x + 2yy' = 0$: $y' = -\frac{x}{y}$.

٢. اشتقّ: $-\frac{1}{y^3} = -\frac{x^2+y^2}{y^3} = -\frac{y+x^2/y}{y^2} = -\frac{y-xy'}{y^2} = y''$.

٣. سالبة دائماً — الدائرة «مقعّرة نحو المركز». ■

- **النتيجة:** $-\frac{1}{y^3}$.
- **الربط بالذكاء الاصطناعي:** «تقوّس القيد» يحدّد ثبات إسقاط التدرّج؛ تقوّس سالب قوي يعني «مساراً مُحاطاً».

مثال (12-5.8).

- **المعطيات:** $y = f(x)$ تحقّق $y' + y = e^{-x}$ مع $y(0) = 1$.
- **المطلوب:** إثبت أنّ $y = e^{-x}(x+1)$ حلّ، وأوجد y'' عند 0.
- **الحل:**

١. تحقّق: $y' = -e^{-x}(x+1) + e^{-x} = -xe^{-x}$؛ $y' + y = e^{-x}(1 - x + x + 1)$... دقّة: $-xe^{-x} + e^{-x}(x+1) = e^{-x}$. ✓

٢. $y'' = (x-1)e^{-x}$؛ عند 0: $y'' = -1$. ■

- **النتيجة:** $y''(0) = -1$.
- **الربط بالذكاء الاصطناعي:** معادلات تفاضلية من الدرجة الأولى تصف «تدفّق التدرّج» (gradient flow)؛ اختبار الحلّ مرّكباً — نمط التحقّق في براهين التقارب.

مثال (13-5.8).

- **المعطيات:** $f(x) = x \arctan x$.
- **المطلوب:** f'' وقيمة $f''(0)$.
- **الحل:**

١. $f' = \arctan x + \frac{x}{1+x^2}$.

٢. $f'' = \frac{1}{1+x^2} + \frac{(1+x^2)-2x^2}{(1+x^2)^2} = \frac{2}{(1+x^2)^2}$.

٣. $f''(0) = 2$. ■

- **النتيجة:** $\frac{2}{(1+x^2)^2}$؛ عند الصفر 2.
- **الربط بالذكاء الاصطناعي:** دوالّ «بإشارة تقوّس موجبة دائماً» (محدّبة) — مثالية كعقوبات (regularizers) لأنّها تملك صغرى وحيدة.

مثال (14-5.8).

- **المعطيات:** $f(x) = \sigma(x)$ (سيجمويد).
- **المطلوب:** f'' وبحث إشارتها (نقطة انعطاف).
- **الحل:**

١. $f' = \sigma(1-\sigma)$.

٢. $f'' = \sigma'(1-2\sigma) = \sigma(1-\sigma)(1-2\sigma)$.

٣. الإشارة تتغيّر عند $\sigma = \frac{1}{2}$ أي $x = 0$ — نقطة انعطاف. ■

- **النتيجة:** انعطاف عند 0، محدّبة قبلها ومقعّرة بعدها.
- **الربط بالذكاء الاصطناعي:** sigmoid «محدّبة في الذيل السالب ومقعّرة في الموجب» — هذا الخليط يجعل الخسارة اللوجستية غير محدّبة عالمياً في الشبكات العميقة.

مثال (15-5.8).

- **المعطيات:** $L(\theta) = \theta^4$.
- **المطلوب:** L'، L''، وتحليل النقطة $\theta = 0$.
- **الحل:**

١. $L' = 4\theta^3$، الصفر عند $\theta = 0$ فقط.

٢. $L'' = 12\theta^2 \geq 0$، عند 0: $L'' = 0$ — اختبار المشتقّ الثاني محايد.

٣. ومع ذلك: $L \geq 0$ و $L(0) = 0 \Longrightarrow$ صغرى عالمية (من الإشارة لا من الاختبار). ■

- **النتيجة:** صغرى عالمية عند 0 رغم $L''(0) = 0$.
- **الربط بالذكاء الاصطناعي:** «وادي مسطّح للدرجة الرابعة» — المحسّنات تتباطأ قرب النقطة (تدرّج $4\theta^3$ يخفت)؛ من هنا تبرير التدريج الرابع (quartic) في تحليل الشحاذة الفائقة (over-parameterized minima).

النظريات

dir="ltr"> <div

Theorem 1.6.8 (Rolle). If f is continuous on $[a,b]$, differentiable on (a,b), and $f(a) = f(b)$, then $\exists c \in (a,b) : f'(c) = 0$.

Theorem 2.6.8 (Mean Value — Lagrange). If f is continuous on $[a,b]$ and differentiable on (a,b), then

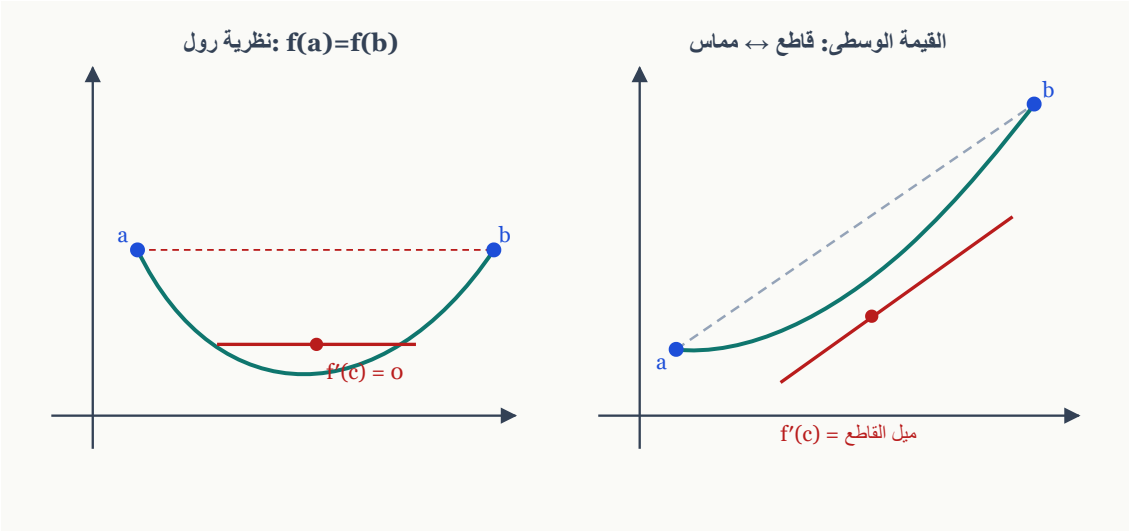
$$\exists\, c \in (a,b) : \quad f'(c) = \frac{f(b) - f(a)}{b - a}.$$

$$f(b) - f(a) = f'(c)\,(b-a) \quad \text{لنقطة} c \in (a,b) \tag{11.8}$$

النظرية 3.6.8 (اختبار المشتقّ الأول). عند نقطة حرجة c (بها $f'(c) = 0$ أو المشتقّ غير موجود): تغيّر إشارة f' من $-$ إلى $+$ يعطي كبرى محلية، ومن $+$ إلى $-$ صغرى محلية.

النظرية 4.6.8 (اختبار المشتقّ الثاني). إذا كانت $f'(c) = 0$ و $f''(c) > 0$ فكبرى... بل **صغرى محلية**؛ و $f''(c) < 0$ كبرى محلية.

<figure> الشكل<figcaption> 3.8: يسار — نظرية رول: قيمتان متساويتان على الطرفين تفرضان نقطة مماس



شكل ٣.٨: *
رول والقيمة الوسطى

أفقي. يمين — القيمة الوسطى: يوجد دائمًا مماس يوازي القاطع الواصل بين الطرفين.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«$f' = 0$ يعني صغرى»	نقاط سرج: x^3 عند 0	فحص تغيّر الإشارة أو f''
«$f'' = 0$ يعني انعطافًا»	x^4 عند 0: $f'' = 0$ وبدون انعطاف	انعطاف = تغيّر إشارة f''
تطبيق MVT دون الاتصال على $[a,b]$	المثال المضاد: دالة قافزة	تحقّق من الفرضيّات
«MVT يعطي كل النقاط»	يعطي وجود نقطة واحدة على الأقل	لا يحدّد عددها

أمثلة محلولة على رول والقيمة الوسطى والنقاط الحرجة (15 مثالاً)

مثال (1-6.8).

- **المعطيات:** $f(x) = x^2 - 4x + 3$ على $[0, 4]$.
- **المطلوب:** نقطة رول c (لاحظ $f(0) = f(4) = 3$).
- **الحل:**

١. $f' = 2x - 4 = 0 \Rightarrow c = 2$.

٢. $2 \in (0,4)$ ✓ و f متصلة وقابلة للاشتقاق. ■

- **النتيجة:** $c = 2$ — رأس القوس (الصغرى).

- **الربط بالذكاء الاصطناعي:** «قوس مربّع بقيم متساوية على الطرفين» هو مصفوفة خسارة تكلفة متساوية عند نقطتين — وجود قاع بينهما مضمون بروول.

مثال (٨.٦-2).

- **المعطيات:** $f(x) = x^3 - 3x$ على $[-\sqrt{3}, \sqrt{3}]$.
- **المطلوب:** نقاط رول.
- **الحل:**

١. $f(\pm\sqrt{3}) = 0$ متساوية.

٢. $f' = 3x^2 - 3 = 0 \Rightarrow x = \pm 1$.

٣. كلتاهما داخل الفترة. ■

- **النتيجة:** $c = \pm 1$.

- **الربط بالذكاء الاصطناعي:** دالة «مزدوجة الآبار» — صورة نموذجية للخسائر ذات حلّين محليين متساويين في مسائل التوليد.

مثال (٨.٦-3).

- **المعطيات:** $f(x) = x^2$ على $[1, 3]$.
- **المطلوب:** نقطة القيمة الوسطى (٨.١١).
- **الحل:**

١. الميل القاطع $= \frac{9-1}{2} = 4$.

٢. $f'(c) = 2c = 4 \Rightarrow c = 2$.

٣. $2 \in (1,3)$ ✓. ■

- **النتيجة:** $c = 2$ — منتصف الفترة (لطبيعة التربيعية).

- **الربط بالذكاء الاصطناعي:** «متوسط السرعة = سرعة لحظية ما في الوسط» يقابل «متوسط الخسارة على الحقب = ميل لحظي ما» — ربط مفهومي للقياس الزمني في التدريب.

مثال (8.6-4).

- **المعطيات:** $f(x) = \ln x$ على $[1, e]$.
- **المطلوب:** c الذي يحقق MVT.
- **الحل:**

١. الميل القاطع $= \frac{1-0}{e-1} = \frac{1}{e-1}$.

٢. $f'(c) = \frac{1}{c} = \frac{1}{e-1} \Rightarrow c = e - 1$.

٣. $e - 1 \approx 1.718 \in (1, e)$ ✓. ■

- **النتيجة:** $c = e - 1$.

- **الربط بالذكاء الاصطناعي:** «أين يساوي ميل اللوغاريتم متوسطه؟» — تحليل معدّل نموّ القياسات اللوغاريتمية في قوانين التوسّع.

مثال (8.6-5).

- **المعطيات:** $f(x) = |x|$ على $[-1, 2]$.
- **المطلوب:** لماذا لا يُطبَّق MVT مباشرة؟ وهل النتيجة صحيحة على أي حال؟
- **الحل:**

١. f متصلة على $[-1, 2]$ لكنها **غير قابلة للاشتقاق** عند 0 داخل الفترة.

٢. فرضيات MVT تنهار (جزئياً).

٣. ومع ذلك توجد c تحقق الميل $\frac{2-1}{3} = \frac{1}{3}$: أيّ $c \in (0, 2)$ حيث $f' = 1 \neq \frac{1}{3}$... لا توجد! لكن على $[-1, 0]$ المشتقّ -1... فلا يوجد c. **MVT فشل فعلاً.** ■

- **النتيجة:** MVT لا يسري؛ الميلان الأحاديان $-1, 1$ لا يحتويان $\frac{1}{3}$.

- **الربط بالذكاء الاصطناعي:** الخسارة $|w|$ (L1): «متوسط التقدّم» قد لا يقابله أيّ تدرّج لحظي — لهذا يعمل L1 ببرمجة محدّبة وليس تدرّجاً ساذجاً.

مثال (8.6-6).

- **المعطيات:** $f(x) = x^3 - 3x^2 + 1$.
- **المطلوب:** النقاط الحرجة وتصنيفها (اختبار المشتقّ الأول).
- **الحل:**

١. $f' = 3x^2 - 6x = 3x(x-2) = 0 \Rightarrow x = 0, 2$.

٢. عند 0: الإشارة $+ \to - \implies$ كبرى محلية $(f = 1)$.

٣. عند 2: الإشارة $- \to + \implies$ صغرى محلية $(f = -3)$. ■

- **النتيجة:** كبرى عند $(0, 1)$، صغرى عند $(2, -3)$.

- **الربط بالذكاء الاصطناعي:** «حوضان» في الخسارة — الوصول للكبرى الوسيطة يمنع الانتقال بين الحوضين؛ لهذا يُضاف «اندفاع» (momentum) لتجاوز العوائق.

مثال (٨.٦-7).

- **المعطيات:** $f(x) = x^4 - 4x^2$.

- **المطلوب:** النقاط الحرجة باختبار المشتقّ الثاني.

- **الحل:**

١. $f' = 4x^3 - 8x = 4x(x^2 - 2) = 0 \Rightarrow x = 0, \pm\sqrt{2}$.

٢. $f'' = 12x^2 - 8$: عند $\pm\sqrt{2}$: $= 16 > 0 \implies$ صغران.

٣. عند 0: $= -8 < 0 \implies$ كبرى. ■

- **النتيجة:** صغران عند $\pm\sqrt{2}$ (قيم -4)، كبرى عند 0 (قيمة 0).

- **الربط بالذكاء الاصطناعي:** «قاعان متماثلان وسرج وسطي» — هندسة W-shape في خسائر ضغط النماذج؛ من نقطة 0 يهرب التدرّج لأحد القاعين عشوائياً (كسر تماثل).

مثال (٨.٦-8).

- **المعطيات:** $f(x) = x + \frac{1}{x}$ على $x > 0$.

- **المطلوب:** الصغرى المحلية.

- **الحل:**

١. $f' = 1 - \frac{1}{x^2} = 0 \Rightarrow x = 1$ (في المجال الموجب).

٢. $f'' = \frac{2}{x^3} > 0 \implies$ صغرى.

٣. $f(1) = 2$. ■

- **النتيجة:** صغرى قيمة 2 عند $x = 1$.

- **الربط بالذكاء الاصطناعي:** «مقايضة» كلاسيكية: خطأ x + تعقيد $\frac{1}{x}$ — تقليل المجموع يعطي التوازن الأمثل (bias-variance) بنسخة منتهية).

مثال (8.6-9).

- **المعطيات:** $f(x) = \sin x$ على $[0, 2\pi]$.
- **المطلوب:** MVT ثم تفسيره هندسياً.
- **الحل:**

١. الميل القاطع $= \frac{0-0}{2\pi} = 0$.

٢. $f'(c) = \cos c = 0 \Rightarrow c = \frac{\pi}{2}, \frac{3\pi}{2}$ — نقطتان.

٣. MVT يضمن واحدة على الأقل؛ هنا اثنتان. ■

- **النتيجة:** $c \in \{\pi/2, 3\pi/2\}$.

- **الربط بالذكاء الاصطناعي:** «دورة كاملة بمتوسط صفري» — الإشارات المتناوبة لا تحمل انحيازاً صافياً، أساس تحليل الضجيج المتعامد في SGD.

مثال (8.6-10).

- **المعطيات:** $f(x) = x^3$ على $[-1, 2]$.
- **المطلوب:** نقطة MVT.
- **الحل:**

١. الميل القاطع $= \frac{8-(-1)}{3} = 3$.

٢. $f'(c) = 3c^2 = 3 \Rightarrow c = \pm 1$.

٣. فقط $c = 1$ داخل الفترة. ■

- **النتيجة:** $c = 1$.

- **الربط بالذكاء الاصطناعي:** دالة «سرج» — MVT يعمل لكن النقطة ليست قاعاً؛ تذكير بعدم مساواة «تدرّج متوسط» بـ «قاع».

مثال (8.6-11).

- **المعطيات:** $f(x) = e^{-x} \sin x$ على $[0, 2\pi]$.
- **المطلوب:** استخدم رول لإثبات وجود c بـ $f'(c) = \cot c$... بل بدقة: ابحث عن نقطة المشتقّ الصفرية المضمونة.
- **الحل:**

١. $f(0) = f(2\pi) = 0$ — فرضيات رول متحققة (متصلة وقابلة للاشتقاق).

٢. $f' = e^{-x}(\cos x - \sin x) = 0 \Rightarrow \tan x = 1 \Rightarrow x = \frac{\pi}{4}, \frac{5\pi}{4}$.

٣. كلتاهما في $(0, 2\pi)$. ■

- **النتيجة:** $c \in \{\pi/4, 5\pi/4\}$.

- **الربط بالذكاء الاصطناعي:** «ذبذبة مُخمّدة» — نقاط سكونها تتقدم دورياً؛ نمط التذبذبات في مسار momentum المكبح.

مثال (8.6-12).

- **المعطيات:** $f(x) = \sqrt{x}$ على $[0, 4]$.

- **المطلوب:** MVT وفحص الاتصال عند 0.

- **الحل:**

١. الميل القاطع $= \frac{2-0}{4} = \frac{1}{2} =:$.

٢. $f'(c) = \frac{1}{2\sqrt{c}} = \frac{1}{2} \Rightarrow c = 1$.

٣. $c = 1 \in (0, 4)$ ✓؛ (عند 0 لا اشتقاق لكن الفرضية على الفترة المفتوحة فقط). ■

- **النتيجة:** $c = 1$.

- **الربط بالذكاء الاصطناعي:** فرضية الاشتقاق على الفترة المفتوحة فقط تسمح بزوايا عند الأطراف — يفسّر نجاح الحسارات ذات الحواف الطرفية.

مثال (8.6-13).

- **المعطيات:** $f(x) = x^{2/3}$ على $[-1, 1]$.

- **المطلوب:** هل توجد نقطة رول؟ $(f(-1) = f(1) = 1)$

- **الحل:**

١. f متصلة على $[-1, 1]$ ✓.

٢. $f' = \frac{2}{3}x^{-1/3}$ غير معرّفة عند 0.

٣. لكن الفرضية تتطلب الاشتقاق على الفترة المفتوحة — يوجد 0 فيها $\Longrightarrow$ رول **لا يُطبَّق**. فعلاً: $f' \neq 0$ في أي مكان معرّف. ■

- **النتيجة:** رول لا يسري؛ لا نقطة بمشتقّ صفري.

- **الربط بالذكاء الاصطناعي:** خسارة «القدرة الثلثية» لها قاع حادّ بلا تدرّج صفري — التدرّج ينتفخ قرب القاع، والوصول إليه يحتاج تقنيات خاصة (proximal).

مثال (14-6.8).

- **المعطيات:** $f(x) = x - \sin x$ على $\mathbb{R}$.
- **المطلوب:** استخدم MVT لإثبات أنّ f تزايدية وأنّ $x = \sin x$ حلّ وحيد.
- **الحل:**

١. $f' = 1 - \cos x \geq 0$، وتساوي 0 عند نقاط معزولة فقط.

٢. MVT: $f(b) - f(a) = f'(c)(b-a) \geq 0$ مع مساواة ممكنة فقط إذا... عملياً f متزايدة تماماً.

٣. $f(0) = 0 \implies$ الحلّ الوحيد $x = 0$. ■

- **النتيجة:** حلّه الوحيد $x = \sin x$ هو 0.

- **الربط بالذكاء الاصطناعي:** «تزايدية صارمة رغم صفارات معزولة» يقابل مساراً تحسينياً لا يرتدّ رغم تدرّجات صفورية لحظية — كفاءة في التقدّم الصافي.

مثال (15-6.8).

- **المعطيات:** خسارة لوجستية لمعاملة واحدة $L(w) = \ln(1 + e^{-w})$ مع وسم $+1$.
- **المطلوب:** L'، L''، وتحليل النقطة الحرجة إن وُجدت.
- **الحل:**

١. $L' = \frac{-e^{-w}}{1+e^{-w}} = -\sigma(-w)$.

٢. $L'' = \sigma(-w)(1 - \sigma(-w)) > 0$ دائماً — محدّبة.

٣. لا نقطة حرجة منتهية؛ الصغرى عند $w \to +\infty$ (حدّية لا بلوغ). ■

- **النتيجة:** محدّبة بلا نقطة حرجة داخلية؛ الصغرى «على اللانهاية».

- **الربط بالذكاء الاصطناعي:** «عصا غير قابلة للفصل خطّياً» تدفع الأوزان إلى ما لا نهاية — لهذا التنظيم L2 ضروري لوجود صغرى منتهية (وجود + معقولية).

خيط الفصل

١. **التعريف (1.8)** هو «حساسية» — كم يتغيّر الخرج لكل تغيّر صغير في المدخل.

٢. **القواعد (3.8)–(5.8)** تحوّل حساسيات مركّبة إلى حواصل ضرب حساسيات بسيطة — وهذا حرفياً الرسم البياني الحسابي (computational graph) الذي يبنيه pytorch.

٣. **قاعدة السلسلة** على شبكة عميقة L طبقة:

$$\frac{\partial L}{\partial a_1} = \frac{\partial L}{\partial a_L} \cdot \prod_{k=2}^{L} \frac{\partial a_k}{\partial a_{k-1}} \tag{12.8}$$

— حاصل ضرب «معاملات تمرير»؛ إن كان كلٌّ منها $< \frac{1}{2}$ انهار المنتج أُسّيّاً (vanishing)، وإن كان كلٌّ منها > 2 انفجر (exploding).

٤. **النقاط الحرجة (6.8)** تفسّر هندسة فضاء الخسارة: آبار، سراج، وهضاب.

٥. **لماذا backprop كفء؟** حساب كل التدرّجات الجزئية لشبكة بعُقد N يحتاج $O(N)$ عملية (مرور عكسي واحد) بدل $O(N^2)$ للفروق المنتهية — هذا هو «اكتشاف «backprop الثوري.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
قاعدة السلسلة (5.8)	الانتشار العكسي (فصل 36) بالكامل
(6.8) $\sigma' = \sigma(1-\sigma)$	تدرّج الطبقة اللوجستية وتلاشيها
المشتقّ الثاني (10.8)	Newton/quasi-Newton و Adam (فصل 40)
رول/MVT (11.8)	براهين تقارب التدرّج وتحليل معدّل التعلم
النقاط الحرجة	نقاط السرج وطرق الهروب منها
$O(N)$ للمرور العكسي	اقتصاديات التدريب الضخم

١. احسب $f'(3)$ من التعريف (1.8) للدالة $f(x) = x^2 - 2x$، ثم بالقواعد، وقارن.

٢. أثبت من التعريف أنّ مشتقّ الثابت صفر، ثم أنّ $(cf)' = cf'$.

٣. وفق التعريف: لماذا لا تكون $f(x) = x|x|$ قابلة للاشتقاق عند 0؟ احسب الميلين الأحاديين. (تلميح: افصل $x \gtrless 0$.)

٤. أوجد f' للدالة $f(x) = x^3 \ln x$ بقاعدة الضرب، وحدّد النقطة التي فيها $f' = 0$.

٥. طبّق السلسلة مرتين: $f(x) = \ln(\sin(e^x))$.

٦. احسب مشتقّ $f(x) = \dfrac{e^x}{1+x^2}$ وقيمة $f'(0)$.

٧. أثبت أنّ $(\cot x)' = -\csc^2 x$ من قاعدة القسمة.

٨. أوجد الميلان الأحاديين لـ $f(x) = \begin{cases} x^2 & x \le 0 \\ \sqrt{x} & x > 0 \end{cases}$ عند 0 واستنتج قابلية الاشتقاق.

٩. اشتقّ ضمنياً: $x^2 + xy + y^2 = 7$ وأوجد y' عند $(1, 2)$.

١٠. اشتقّ ضمنياً: $\cos(xy) = y$ وأوجد y' كدالة في x, y.

١١. أوجد y'' للدالة الضمنية $y^2 = x^3$ (منحنى نصف تكعيبي) عند النقطة $(1, 1)$.

١٢. احسب $f^{(4)}(0)$ للدوال: e^{2x}، $\cos x$، $\frac{1}{1+x}$.

١٣. أثبت برووِل أنّ $x^5 + x - 1$ لها جذر وحيد في $(0, 1)$.

١٤. طبّق MVT على $f(x) = \arctan x$ على $[0, 1]$ وأوجد c.

١٥. استخدم MVT لإثبات: $|\sin a - \sin b| \le |a - b|$ لكل a, b.

١٦. أوجد النقاط الحرجة وتصنيفها للدالة $f(x) = x^3 - 6x^2 + 9x + 1$ (اختبارا الأول والثاني).

١٧. أوجد النقاط الحرجة للدالة $f(x) = \frac{x^2+1}{x}$ على $x > 0$ وصنّفها، واستنتج متباينة AM–GM.

١٨. أثبت أنّ $f(x) = x + \ln x$ تزايدية تماماً على $(0, \infty)$ وأنّ معادلة $x + \ln x = 3$ لها حلّ وحيد، وأقدّره بين عددين متتاليين.

١٩. «مقايضة»: لخسارة $L(\eta) = \frac{a}{\eta} + b\eta$ (η معدّل التعلّم، $a, b > 0$)، أوجد η^* التي تصغّر L وقيمة $L(\eta^*)$، وفسّر النتيجة بلغة «تضارب التحيّز والتباين».

٢٠. تحدٍّ تركيبي: شبكتان من طبقتين لكل منهما، بحيث $\frac{\partial a_2}{\partial a_1} = c$ في كل طبقة. لكل $c \in \{0.1, 0.5, 1, 2, 10\}$ احسب معامل التمرير الكلي عبر 20 طبقة، وصنّف الحالة (تلاشي/ثبات/انفجار)، ثم اربط النتيجة بمعادلة (12.8) وبأسباب ظهور LSTM و ReLU.

- **التعريف (1.8):** المشتقّ = نهاية الميول القاطعة؛ الاشتقاق $\Longrightarrow$ الاتصال (والعكس خطأ).
- **القواعد (3.8)–(5.8):** جمع وضرب وقسمة وسلسلة؛ السلسلة هي «القانون الأم» لكل ما هو عميق.
- **الجدول الأولي:** مشتقّات x^n، الأسّيات، اللوغاريتمات، المثلثيات، والعكسية منها، مع σ' و $\tanh'$ كأدوات تعلّم.
- **الضمني والأعلى (9.8)–(10.8):** اشتقاق المنحنيات المربوطة، ومشتقّات عليا تقيس التقوّس.
- **البنية (11.8):** رول والقيمة الوسطى يربطان المتوسط بالمحلي، ويضمنان نقاطاً بمشتقّ محدّد.
- **الهندسة:** النقاط الحرجة = آبار وقمم وسراج؛ اختبارات الإشارة والقيمة الثانية تصنّفها.

الرمز	المعنى	أين عُرّف
$f'(a)$	المشتقّ عند نقطة	(1.8)
$f'_{\pm}(a)$	الميلان الأحادية	(2.8)
$(fg)'$	قاعدة الضرب	(3.8)
$(f/g)'$	قاعدة القسمة	(4.8)
$(g \circ f)'$	قاعدة السلسلة	(5.8)
σ'	مشتقّ السيجمويد	(6.8)
$f^{(n)}$	المشتقّ n-ي	(10.8)
$\prod \partial a_k/\partial a_{k-1}$	معامل التمرير الكلي	(12.8)

١. I. Newton, (1687). *Mathematica Principia Naturalis Philosophiæ* — أول استخدام منهجي للحدّيات اللحظية (بصياغة هندسية).

٢. W. G. Leibniz, (1684). "Nova Methodus pro Maximis et Minimis" — صياغة $\frac{dy}{dx}$ والقواعد الجبرية.

٣. J.-L. Lagrange, (1797). *Théorie des fonctions analytiques* — صياغة المشتقّ كنهاية ونظرية القيمة الوسطى.

٤. M. Spivak, (2008). *Calculus*, 4th ed., Perish or Publish (الفصول 9–11: المشتقّ، القواعد، القيمة الوسطى — أدقّ المعالجات التعليمية).

٥. J. Stewart, (2015). *Early Transcendentals Calculus*, 8th ed., Cengage (مرجع الجداول والتمارين التطبيقية).

٦. R. Williams, & G. Hinton, D., Rumelhart, (1986). "Learning representations by back-propagating errors". *Nature* 323 — الورقة المؤسِّسة للانتشار العكسي.

٧. A. Courville, & Y. Bengio, I., Goodfellow, (2016). *Deep Learning*, MIT Press (الفصل 6.5: قاعدة السلسلة والرسم البياني الحسابي؛ الفصل 8: نقاط السرج والمحسّنات).

٨. A. Walther, & A. Griewank, (2008). *Evaluating Derivatives*, 2nd ed., SIAM (التفاضل الآلي: الأمامي مقابل العكسي وتكلفة $O(N)$).

التفاضل المصفوفي: اليعقوبية، الهِسّية، وقواعد السلسلة

الهدف من الفصل

ثالث فصول الجزء الثاني. النهايات (7) والمشتقّ القياسي (8) جاهزان؛ الآن نرفع كل شيء إلى عالم المصفوفات — لغة الشبكات العصبية الفعلية. كل معادلة تحديث أوزان في pytorch أو tensorflow هي تطبيق مباشر لقواعد هذا الفصل.

ثلاثة مواقف:

١. **تدرّج الشبكة** ليس عدداً بل **مصفوفة** (أو موتراً): كل معامل لكل وزن لكل طبقة. اليعقوبية هي «كائن التفاضل» الصحيح في هذا العالم.

٢. **الهِسّية** (مصفوفة المشتقّات الثانية) تحكم «شكل الحوض» حول النقطة الحرجة — منها يأتي تحليل التقوّس، وطرق Newton، وشحاذة النقاط السرج.

٣. **softmax** و **LayerNorm** و **attention** كلها دوالّ متجهية→متجهية؛ تدرّجها معروف بالصيغ المصفوفية التي سنبنيها هنا (مثلاً softmax Jacobian الشهير $\operatorname{diag}(s) - ss^\top$).

خريطة الفصل

القسم	الموضوع	الأداة
2.9	اليعقوبية: تعريف وبنية	مصفوفة المشتقّات الجزئية
3.9	الهِسّية والتقوّس	مصفوفة ثانية + تحليل طيفي
4.9	قاعدة السلسلة المصفوفية	ضرب اليعقوبيات
5.9	مشتقّات العمليات المصفوفية	أثر/محدّد/نُرم
6.9	التطبيقات: least squares و softmax	حساب تدرّجات حقيقية
7.9	التجميع: المحسّنات كتطبيق	تجميع

التعريف

dir="ltr"> <div

Definition 1.2.9. For $\mathbf{f} : \mathbb{R}^n \to \mathbb{R}^m$ with components f_i, the Jacobian matrix is: $J \in \mathbb{R}^{m \times n}$

$$J_{ij} = \frac{\partial f_i}{\partial x_j}.$$

$$J_{\mathbf{f}}(\mathbf{x}) = \begin{bmatrix} \dfrac{\partial f_1}{\partial x_1} & \cdots & \dfrac{\partial f_1}{\partial x_n} \\ \vdots & & \vdots \\ \dfrac{\partial f_m}{\partial x_1} & \cdots & \dfrac{\partial f_m}{\partial x_n} \end{bmatrix} \tag{1.9}$$

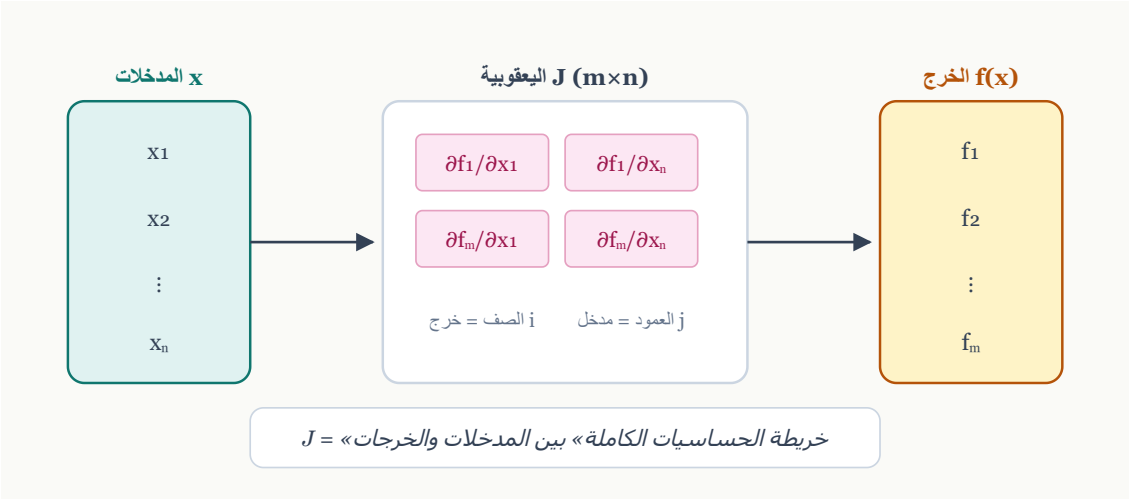
- الصف i = حساسيات الخرج f_i تجاه كل المدخلات.
- التدرّج القياسي $\nabla_x f$ (لمتجه x ودالة سلمية f) هو **متجه صفّ** — حالة خاصة $m = 1$.
- **النظرية 1.2.9:** $\mathbf{f}$ قابلة للاشتقاق (فروبيوس) عند $\mathbf{x}$ $\iff$ اليعقوبية موجودة والحدّ الخطّي الأول يصف التغيّر: $\mathbf{f}(\mathbf{x}+\Delta) = \mathbf{f}(\mathbf{x}) + J\,\Delta + o(\|\Delta\|)$.

جدول الرموز

الرمز	الاسم	المعنى
$J_{\mathbf{f}}$	اليعقوبية	$m \times n$ من الحساسيات
$\nabla_{\mathbf{x}} f$	التدرّج	متجه صف $1 \times n$ $(m = 1)$
$\partial \mathbf{u}/\partial \mathbf{v}$	اليعقوبية المعمّمة	حساسية متجه داخل متجه

رسم توضيحي

<figure> الشكل<figcaption> 1.9: اليعقوبية جدولٌ حسابي — الصف = خرج واحد، العمود = مدخل



شكل ١.٠٩: *
اليعقوبية كحصاد الحساسيات

واحد؛ الخلية J_{ij} = «كم يتغيّر الخرج i إذا تحرّك المدخل j». المحسّنات تقرأ العمود الخاص بالمعامل الذي تريد تحديثه.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الخلط بين اليعقوبية والتدرّج	التدرّج حالة خاصة $(m = 1)$	التدرّج صفّ؛ اليعقوبية $m \times n$
اتجاه اليعقوبية في السلسلة	ضرب J في «الاتجاه الصحيح»	سلسلة الأمامية: $J_{g\circ f} = J_g \cdot J_f$
افتراض تماثل J	التماثل خاصية الهِسّية غالباً	J عامّة غير متماثلة
نسيان الاعتماد على النقطة	$J = J(\mathbf{x})$ — تتغيّر مع كل خطوة	تُحسب في كل تكرار

أمثلة محلولة على اليعقوبية (15 مثالاً)

مثال (9.2-1).

- **المعطيات:** $\mathbf{f}(x_1, x_2) = (x_1^2,\ x_1 x_2)^\top$.
- **المطلوب:** اليعقوبية.
- **الحل:**

١. صفّ الخرج الأول: $(2x_1,\ 0)$.

٢. صفّ الخرج الثاني: $(x_2,\ x_1)$.

٣. $J = \begin{bmatrix} 2x_1 & 0 \\ x_2 & x_1 \end{bmatrix}$. ■

- **النتيجة:** مصفوفة 2×2 تعتمد على النقطة.
- **الربط بالذكاء الاصطناعي:** هذه بنية طبقة خطية مربّعة صغيرة؛ الحساسيات «تتجدد» في كل خطوة — لا مشتقّ واحد يدوم.

مثال (9.2-2).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = A\mathbf{x}$ حيث $A \in \mathbb{R}^{m \times n}$ ثابتة.
- **المطلوب:** اليعقوبية.
- **الحل:**

١. $\frac{\partial f_i}{\partial x_j} = A_{ij} \Longrightarrow f_i = \sum_j A_{ij} x_j$.

٢. $J = A$. ■

- **النتيجة:** يعقوبية التحوّل الخطّي هي المصفوفة نفسها — ثابتة.
- **الربط بالذكاء الاصطناعي:** لطبقة خطية «التدرّج = الأوزان»؛ لذلك تمرير الإشارة عبر الطبقة الخطية يعني الضرب بـ W (أمامياً) أو $W^\top$ (عكسياً).

مثال (9.2-3).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathbf{x}$ (الهوية في $\mathbb{R}^n$).
- **المطلوب:** اليعقوبية.
- **الحل:** $J = I_n$. ■
- **النتيجة:** الهوية $\Longrightarrow$ مصفوفة الوحدة.
- **الربط بالذكاء الاصطناعي:** «تخطّي» (skip/residual) يمرّر الهوية: تدرّجه = الوحدة — السبب الرياضي لنجاح ResNet في إنقاذ التدرّجات.

مثال (9.2-4).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \sigma(A\mathbf{x} + \mathbf{b})$ عنصراً بعنصر (سيجمويد).
- **المطلوب:** اليعقوبية وتبسيطها.
- **الحل:**

١. لكل خرج i: $\frac{\partial f_i}{\partial x_j} = \sigma(z_i)(1 - \sigma(z_i))A_{ij}$ حيث $z = A\mathbf{x} + \mathbf{b}$.

٢. $J = \operatorname{diag}(\sigma(z)(1 - \sigma(z)))\, A$. ■

- **النتيجة:** قطرية × المصفوفة.
- **الربط بالذكاء الاصطناعي:** هذا «سطر backprop للطبقة الكلاسيكية: تدرّج التنشيط (قطري) ثم الأوزان — الانخفاض بمعامل $\leq \frac{1}{4}$ لكل طبقة (تلاشي sigmoid).

مثال (9.2-5).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathrm{ReLU}(\mathbf{x})$ عنصراً بعنصر.
- **المطلوب:** اليعقوبية (شبه-مشتقّ).
- **الحل:**

١. $\frac{\partial f_i}{\partial x_j} = \mathbb{1}[x_i > 0]\, \delta_{ij}$ (مع اختيار فرعي عند 0).

٢. $J = \operatorname{diag}(\mathbf{1}[\mathbf{x} > 0])$ — قطريّة 0/1. ■

- **النتيجة:** قناع ثنائي قطري.
- **الربط بالذكاء الاصطناعي:** backprop عبر ReLU = «مرور عبر الأبواب المفتوحة فقط» — الوحدات الميتة (0 دائماً) تُغلق المسار نهائياً.

مثال (9.2-6).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathbf{x}^\top \mathbf{x}$ (سلمية).
- **المطلوب:** التدرّج $\nabla_{\mathbf{x}}$.
- **الحل:**

١. $\frac{\partial f}{\partial x_i} = 2x_i \Longrightarrow f = \sum_i x_i^2$.

٢. $\nabla_{\mathbf{x}} f = 2\mathbf{x}^\top$ (صفّ). ■

- **النتيجة:** $2\mathbf{x}^\top$.
- **الربط بالذكاء الاصطناعي:** تدرّج أي خسارة تربيعية = ضعف المتجه؛ قاعدة $\frac{1}{2}$ في تعريف MSE ليست ترفاً — لإلغاء 2.

مثال (9.2-7).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathbf{x}^\top A\mathbf{x}$ مع A متماثلة.
- **المطلوب:** التدرّج.
- **الحل:**

١. توسيع: $f = \sum_{i,j} A_{ij}x_i x_j$؛ الاشتقاق الجزئي يعطي $\frac{\partial f}{\partial x_k} = 2\sum_j A_{kj}x_j$.

٢. $\nabla f = 2\,\mathbf{x}^\top A$. ■

- **النتيجة:** $2\mathbf{x}^\top A$ (لـ A متماثلة؛ عامّةً $\mathbf{x}^\top(A + A^\top)$).
- **الربط بالذكاء الاصطناعي:** أشكال الطاقة التربيعية؛ تدرّجها «قوة خطّية» — أساس الأنظمة الديناميكية المستقرة و regularization المربّعة.

مثال (9.2-8).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \begin{pmatrix} e^{x_1}\cos x_2 \\ e^{x_1}\sin x_2 \end{pmatrix}$ (تحويل قطبي).
- **المطلوب:** اليعقوبية ومحدّدها.
- **الحل:**

١. $J = \begin{bmatrix} e^{x_1}\cos x_2 & -e^{x_1}\sin x_2 \\ e^{x_1}\sin x_2 & e^{x_1}\cos x_2 \end{bmatrix}$.

٢. $\det J = e^{2x_1}$ (دائمًا > 0). ■

- **النتيجة:** اليعقوبية = دوران × تمدد؛ المحدّد موجب.
- **الربط بالذكاء الاصطناعي:** «مراوح التدفّق الطبيعي» (normalizing flows) تُبنى من تحويلات يسهل حساب محدّد يعقوبيتها؛ هذا المثال نموذج كامل لذلك.

مثال (9.2-9).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \dfrac{\mathbf{x}}{\|\mathbf{x}\|_2}$ (التطبيع الشعاعي) عند $\mathbf{x} \neq 0$.
- **المطلوب:** اليعقوبية.
- **الحل:**

١. $f_i = x_i r^{-1}$، $r = \|\mathbf{x}\|$.

٢. $\frac{\partial f_i}{\partial x_j} = \frac{\delta_{ij}}{r} - \frac{x_i x_j}{r^3}$.

٣. $J = \frac{1}{r}\left(I - \hat{\mathbf{x}}\hat{\mathbf{x}}^\top\right)$. ■

- **النتيجة:** إسقاط على المستوي العمودي على $\hat{\mathbf{x}}$، مضروباً بـ $\frac{1}{r}$.

- **الربط بالذكاء الاصطناعي:** تطبيع (cosine Embedding similarity) — الحساسية عمودية على الاتجاه؛ لهذا «تحريك الطول» لا يغيّر التشابه الكوسيني.

مثال (9.2-10).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \ln \sum_i e^{x_i} \cdot \mathbf{1}$ (المتجه الثابت ؟(LSE لا — خذ $f(\mathbf{x}) = \log \sum_i e^{x_i}$ سلمية.

- **المطلوب:** التدرّج.

- **الحل:**

١. $\frac{\partial f}{\partial x_k} = \frac{e^{x_k}}{\sum_i e^{x_i}} = \text{softmax}(\mathbf{x})_k$.

٢. $\nabla f = \mathbf{s}^\top$ حيث $\mathbf{s} = \text{softmax}(\mathbf{x})$. ■

- **النتيجة:** تدرّج LSE هو softmax.

- **الربط بالذكاء الاصطناعي:** الازدواجية الجملية LSE–softmax: مشتقّ أحدهما هو الآخر — أساس مرور backprop في softmax-crossentropy (مثال 9.6-3).

مثال (9.2-11).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = A\mathbf{x} - \mathbf{y}$.

- **المطلوب:** اليعقوبية بالنسبة إلى $\mathbf{x}$.

- **الحل:** $J = A$ ($\mathbf{y}$ ثابتة). ■

- **النتيجة:** A.

- **الربط بالذكاء الاصطناعي:** بقايا النموذج الخطّي؛ يعقوبيتها ثابتة — لهذا مشاكل المربعات الصغرى «لطيفة» (تحليلها خطّي بالكامل).

مثال (9.2-12).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = (\mathbf{x}^\top \mathbf{x})\,\mathbf{x}$ (متجه مقياس متجه).

- **المطلوب:** اليعقوبية.

- **الحل:**

١. $f_i = r^2 x_i$؛ $\frac{\partial f_i}{\partial x_j} = 2x_j x_i + r^2 \delta_{ij}$.

٢. $J = r^2 I + 2\mathbf{x}\mathbf{x}^\top$. ■

- **النتيجة:** قطرية + رتبة واحدة.
- **الربط بالذكاء الاصطناعي:** بنية «قياس × بُعد» تظهر في خرائط القياس؛ يعقوبيتها رتبة-واحدة تحتها — طيف قابل للتحليل بقيم ذاتية بسيطة.

مثال (9.2-13).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \begin{pmatrix} x_1 + x_2 \\ x_1 x_2 \end{pmatrix}$.
- **المطلوب:** اليعقوبية ونقاط الشذوذ (يعقوبية شاذّة).
- **الحل:**

١. $J = \begin{bmatrix} 1 & 1 \\ x_2 & x_1 \end{bmatrix}$.

٢. $\det J = x_1 - x_2$؛ يصفُر على الخط $x_1 = x_2$. ■

- **النتيجة:** على ذلك الخط ينهار التحويل (بُعد مفقود).
- **الربط بالذكاء الاصطناعي:** «خطّ شذوذ اليعقوبية» يقابل نقاط انهيار التمييز في شبكات التوليد — حيث تتلاصق الخرائط.

مثال (9.2-14).

- **المعطيات:** $f(\mathbf{x}) = \|\mathbf{x}\|_1 = \sum_i |x_i|$.
- **المطلوب:** التدرّج (subgradient) والنقاط الحرجة.
- **الحل:**

١. لكل $x_i \neq 0$: $\frac{\partial f}{\partial x_i} = \operatorname{sgn}(x_i)$.

٢. عند $x_i = 0$: أيّ قيمة في $[-1, 1]$ صالحة (مجموعة subgradient).

٣. $\nabla = \operatorname{sgn}(\mathbf{x})^\top$ (باستثناء الصفريات). ■

- **النتيجة:** إشارة — بلا قيم قرب الصفر.
- **الربط بالذكاء الاصطناعي:** لاسو (L1): التدرّج لا «يصغر» قرب الصفر — لهذا يضغط الأوزان إلى صفر تماماً (تناثر) بخلاف L2.

مثال (9.2-15).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathbf{W}\sigma(\mathbf{V}\mathbf{x})$، مقياس مدخل $\mathbf{x} \in \mathbb{R}^n$، σ عنصرية.
- **المطلوب:** اليعقوبية الكاملة بقاعدة السلسلة.
- **الحل:**

١. طبقة داخلية: $\mathbf{z} = \mathbf{V}\mathbf{x}$، $J_z = \mathbf{V}$.

٢. تنشيط: $J_\sigma = \operatorname{diag}(\sigma'(\mathbf{z}))$.

٣. خارجية: $J = \mathbf{W}\operatorname{diag}(\sigma'(\mathbf{z}))\,\mathbf{V}$. ■

- **النتيجة:** حاصل ضرب ثلاث مصفوفات — «شبكة من طبقتين».
- **الربط بالذكاء الاصطناعي:** هذه هي backprop مضغوطة: مرور أمامي يعطي $\mathbf{z}$، ثم اليعقوبية تُبنى من المخرجات المتاحة أصلاً — لا إعادة حساب.

التعريف

dir="ltr"> <div

Definition 9.3.1. (Hessian) For a twice-dffierentiable scalar function $f : \mathbb{R}^n \to \mathbb{R}$:

$$H_{ij} = \frac{\partial^2 f}{\partial x_i \, \partial x_j}.$$

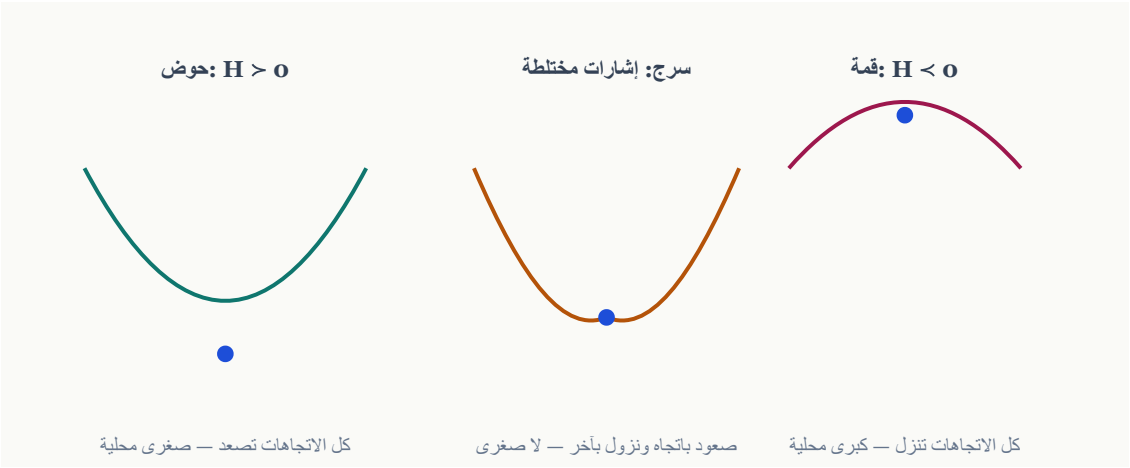
$$H_f(\mathbf{x}) = \nabla^2 f = \begin{bmatrix} \dfrac{\partial^2 f}{\partial x_1^2} & \cdots & \dfrac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & & \vdots \\ \dfrac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \dfrac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \tag{2.9}$$

النظرية 9.3.1 (تماثل شوارتز). إذا كانت المشتقّات الثانية متصلة فإنّ H **متماثلة**: $H_{ij} = H_{ji}$ — ويتبع عندها التحليل الطيفي (فصل 4).

النظرية 9.3.2 (التقوّس والهِسّية). f محدّبة على مجموعة محدّبة مفتوحة $\iff H \succeq 0$ (شبه موجبة) في كل نقطة؛ ومحدّبة تماماً إذا كانت $H \succ 0$.

النظرية 9.3.3 (الشكل الثاني يصنّف النقطة الحرجة). عند نقطة $\nabla f = 0$:

- $H \succ 0 \implies$ صغرى محلية (حوض).
- $H \prec 0 \implies$ كبرى محلية (قمة).
- إشارات مختلطة $\implies$ **نقطة سرج**.
- H شبه موجبة مفردة $\implies$ غير حاسمة (تحتاج فحصاً أعلى).



شكل ٢.٩: *
الهِسّية تصنّف النقطة الحرجة

رسم توضيحي

<figure> الشكل<figcaption> 2.9: الهِسّية كـ«عدسة تقوّس» — في الحوض كل الاتجاهات تصعد ($H \succ 0$)؛ في السرج تصعد بعض الاتجاهات وتنزل أخرى (H بإشارات مختلطة)؛ على القمة تنزل كل الاتجاهات ($H \prec 0$).</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«H موجبة عند نقطة حرجة $\Rightarrow$ صغرى **عالمية**»	فقط محلية؛ الشمولية تحتاج محدّبة	محدّبة $f + 0 \succeq H \Rightarrow$ عالمية
«$\nabla f = 0$ و $H \succeq 0 \Rightarrow$ صغرى»	في الحقيقة يحتاج حذراً: $x^4 + y^4$ عند x^3 0...	$H \succ 0$ هي الشرط الحاسم؛ $\succeq 0$ بلا فحص إضافي
نسيان التماثل قبل التحييد الطيفي	التحليل يفترض متماثلة	استخدم $\frac{H+H^\top}{2}$ عددياً
حساب H لشبكة ضخمة	معاملات $O(n^2)$	بدائل: تقديرات (Adam)، منتجات Hessian-vector

أمثلة محلولة على الهِسّية والتقوّس (15 مثالاً)

مثال (3.9-1).

- **المعطيات:** $f(x, y) = x^2 + 4y^2$.
- **المطلوب:** الهِسّية والتصنيف عند النقطة الحرجة.
- **الحل:**

١. $\nabla f = (2x, 8y) \Rightarrow$ نقطة حرجة وحيدة $(0, 0)$.

٢. $H = \begin{bmatrix} 2 & 0 \\ 0 & 8 \end{bmatrix} \succ 0$.

٣. صغرى محلية (وعالمية — محدّبة). ■

- **النتيجة:** صغرى عند الأصل.

• **الربط بالذكاء الاصطناعي:** «حوض مُستطيل»: القيم الذاتية $2, 8$ تحكم سرعة النزول بكل اتجاه، الاختلاف 4× يبطئ الاتجاه الضيق — فكرة conditioning التي عالجناها بالضبط المسبق.

مثال (9.3-2).

• **المعطيات:** $f(x, y) = x^2 - y^2$.

• **المطلوب:** الهِسّية والتصنيف.

• **الحل:**

١. $H = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$: قيم ذاتية ± 2 مختلطة.

٢. النقطة الحرجة $(0, 0)$ نقطة **سرج**. ■

• **النتيجة:** سرج — لا صغرى ولا كبرى.

• **الربط بالذكاء الاصطناعي:** النقاط السرجية هي «القاع» الفعلي للشبكات الكبيرة (ليس الحد الأدنى المحلي المنفرد)؛ أساس السؤال «لماذا تصل SGD إلى سراج؟» — والجواب في أبعاد عالية أصبحت قاعاً بنيوياً.

مثال (9.3-3).

• **المعطيات:** $f(x, y) = x^4 + y^4 - 4xy$.

• **المطلوب:** النقاط الحرجة وتصنيفها.

• **الحل:**

١. $\nabla = (4x^3 - 4y,\ 4y^3 - 4x) = 0 \implies y = x^3$ و $x = y^3 \implies x = x^9 \implies x \in \{0, \pm 1\}$.

٢. $H = \begin{bmatrix} 12x^2 & -4 \\ -4 & 12y^2 \end{bmatrix}$.

٣. عند $(0, 0)$: $\det = -16 < 0$ سرج؛ عند $(1, 1)$ و $(-1, -1)$: $\det = 128 > 0$ و $H_{11} > 0 \implies$ صغران. ■

• **النتيجة:** سرج مركزي وقاعان متناظران.

• **الربط بالذكاء الاصطناعي:** هندسة «سرج يفصل قاعين» في مسائل التماثل (وزن إيجابي أم سلبي؟) — كسر التماثل عشوائياً يختار قاعاً.

مثال (9.3-4).

• **المعطيات:** $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top A\mathbf{x} - \mathbf{b}^\top\mathbf{x}$ مع $A \succ 0$.

- **المطلوب:** التدرّج والهِسّية والحل الأمثل.
- **الحل:**

١. $\nabla f = A\mathbf{x} - \mathbf{b}$؛ $H = A$.

٢. الحل: $A\mathbf{x} = \mathbf{b} \implies \mathbf{x}^* = A^{-1}\mathbf{b}$.

٣. محدّبة تماماً $\implies$ الصغرى وحيدة وعالمية. ■

- **النتيجة:** $\mathbf{x}^* = A^{-1}\mathbf{b}$.

- **الربط بالذكاء الاصطناعي:** هذه «المشكلة التربيعية الأم» — خسارة الانحدار الخطّي بحلّها المغلق (المعادلات الطبيعية) وقاعدتها لمحسّنات Newton وطريقة المقارنة المثالية (polynomial conditioning) من فصل 6).

مثال (9.3-5).

- **المعطيات:** $f(x, y) = e^{x+y}$.
- **المطلوب:** الهِسّية والتقوّس.
- **الحل:**

١. كل المشتقّات الثانية $= e^{x+y}$.

٢. $H = e^{x+y}\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \succeq 0$ (مفردة).

٣. محدّبة (غير تماماً) في كل $\mathbb{R}^2$. ■

- **النتيجة:** محدّبة بلا حوض مغلق — «مستوٍ مائل» في اتجاه $(1, 1)$.

- **الربط بالذكاء الاصطناعي:** خسارة أُسّية غير مقيدة؛ لذلك نأخذ لوغاريتمها قبل التحسين (log-space) لتحويلها إلى مشكلة خطّية.

مثال (9.3-6).

- **المعطيات:** $f(x, y) = \ln(x^2 + y^2 + 1)$.
- **المطلوب:** الهِسّية والتصنيف عند الأصل.
- **الحل:**

١. $\nabla f = \frac{2(x,y)}{r^2+1}$؛ الأصل نقطة حرجة.

٢. بعد الحساب: $H_{ij} = 2\left(\frac{\delta_{ij}}{r^2+1} - \frac{2x_i x_j}{(r^2+1)^2}\right)$.

٣. عند الأصل: $H = 2I \succ 0 \implies$ صغرى. وعالمياً ($f(0) = 0 \leq f$). ■

- **النتيجة:** صغرى عالمية عند الأصل بقيمة 0.

- **الربط بالذكاء الاصطناعي:** «لوغاريتم نُرم مربّعة + 1» — شكل LayerNorm التربيعي؛ مقعّر مركزياً وسلس — أخف من مربّع خالص.

مثال (9.3-7).

- **المعطيات:** $f(x, y) = x^3$.
- **المطلوب:** الهِسّية وتحليل $(0, 0)$.
- **الحل:**

١. $H = \begin{bmatrix} 6x & 0 \\ 0 & 0 \end{bmatrix}$؛ عند الأصل $H = 0$.

٢. الاختبار الثاني محايد.

٣. التحليل المباشر: x^3 سالبة لجانب وموجبة لآخر $\implies$ لا صغرى. ■

- **النتيجة:** $H = 0$ لا تكفي؛ الشكل الثالث (الدرجة الفردية) حاسم.

- **الربط بالذكاء الاصطناعي:** «هضاب فردية الدرجة» تُغشّ الاختبار الثاني؛ أدوات الذيل الأعلى (ثوابت شريطية) لازمة في تحليل أدقّ للمساحات المسطّحة.

مثال (9.3-8).

- **المعطيات:** $f(\mathbf{x}) = \|\mathbf{x}\|_2^2$.
- **المطلوب:** الهِسّية.
- **الحل:** $H = 2I$ (مثال 9.2-6 مرتين). ■
- **النتيجة:** $2I$ — أكثف محدّب ممكن (قيم ذاتية متساوية).

- **الربط بالذكاء الاصطناعي:** «لا تحيّز اتجاهي»: قيم ذاتية متساوية تعني تساوي مقاومة كل الاتجاهات — لهذا regularization المربّع هو «الأدنى تفضيلاً» بين العقوبات السهلة التحليل.

مثال (9.3-9).

- **المعطيات:** $f(x, y) = \frac{x^2}{a^2} + \frac{y^2}{b^2}$.

- **المطلوب:** الهِسّية والقيم الذاتية و«الـ conditioning».
- **الحل:**

١. $H = \operatorname{diag}\left(\frac{2}{a^2}, \frac{2}{b^2}\right)$.

٢. القيم الذاتية كما هي؛ $\kappa = \frac{b^2}{a^2}$ (بافتراض $b > a$).

٣. κ كبير $\Longrightarrow$ «وادٍ ضيّق» — بطء Descent nesterov/Gradient مع معدّل واحد. ■

- **النتيجة:** conditioning $= b^2/a^2$.

- **الربط بالذكاء الاصطناعي:** جسر مباشر إلى فصل 6: عدد الشرط المصفوفي يفسّر أسبوعيات التدريب البطيئة؛ Adam يعادل فعلياً القيم الذاتية (تحديد مسبق عنيف).

مثال (3.9-10).

- **المعطيات:** $f(x, y) = xy$.
- **المطلوب:** الهِسّية والنقطة الحرجة.
- **الحل:**

١. $\nabla = (y, x)$؛ الحرجة $(0, 0)$.

٢. $H = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$؛ قيم ذاتية ± 1.

٣. سرج. ■

- **النتيجة:** سرج بحِسّية متساوية ومتعاكسة.

- **الربط بالذكاء الاصطناعي:** «ضرب متغيرين» نموذج سرج — نفس بنية $w_1 w_2$ في دوالّ الخسارة غير المحدّبة البسيطة؛ لاحظ أنّ $|xy|$ له قاع «خطّي».

مثال (3.9-11).

- **المعطيات:** $f(x, y) = x^4 + y^2 - 2x^2$.
- **المطلوب:** نقاط حرجة وتصنيفها.
- **الحل:**

١. $\nabla = (4x^3 - 4x,\ 2y) = (0, 0) \Longrightarrow y = 0,\ x \in \{0, \pm 1\}$.

٢. $H = \operatorname{diag}(12x^2 - 4,\ 2)$.

٣. عند $(0, 0)$: $H_{11} = -4$ سرج؛ عند $(\pm 1, 0)$: $H_{11} = 8 > 0$ صغران بقيمة -1. ■

- **النتيجة:** قاعان عند $x = \pm 1$، سرج عند الأصل.

- **الربط بالذكاء الاصطناعي:** «وادي مزدوج بسرج وسطي» — التماثل بين القاعين (للاطّلاع: f زوجية) يجعل الأصل نقطة غير مستقرة؛ عشوائية التهيئة تُخرج المسار من السرج.

مثال (9.3-12).

- **المعطيات:** $f(x,y) = x^2 y^2$.
- **المطلوب:** النقاط الحرجة والتصنيف (حذر: H صفري على المحاور).
- **الحل:**

١. $\nabla = (2xy^2, 2x^2y) = (0,0)$ على المحورين كلهما — خط حرج.

٢. $H = \begin{bmatrix} 2y^2 & 4xy \\ 4xy & 2x^2 \end{bmatrix}$، على المحاور H لها صفر قيم ذاتية.

٣. $f \geq 0$ دائماً و $f = 0$ على المحورين $\Longrightarrow$ صغرى (عالمية) على الخطّين. ■

- **النتيجة:** صغرى عالمية على المحورين؛ غير «معزولة».

- **الربط بالذكاء الاصطناعي:** «حدّ أدنى على منحنى» — انعكاس شائع للشبكات الفائقة التعدّد: مجموعة حلول لا نقطة؛ لهذا نضيف تنظيم $+\lambda\|w\|^2$ لاختيار حلّ معيّن (الأصغر نُرماً).

مثال (9.3-13).

- **المعطيات:** $f(x,y) = x\ln(x) + y\ln(y)$ (إنتروبيا سلبية) على $x, y > 0$.
- **المطلوب:** الهِسّية والتقوّس.
- **الحل:**

١. $H = \operatorname{diag}\left(\frac{1}{x}, \frac{1}{y}\right) \succ 0$.

٢. محدّبة تماماً على الربع الموجب. ■

- **النتيجة:** محدّبة تماماً.

- **الربط بالذكاء الاصطناعي:** «الإنتروبيا مقعّرة» $\Longrightarrow$ الإنتروبيا السلبية محدّبة — هذا يضمن أنّ أغراض الاستفادة القصوى (تعظيم الإنتروبيا) مسائل محدّبة سهلة الحل (max-ent).

مثال (9.3-14).

- **المعطيات:** $f(x,y) = \frac{1}{2}\|\mathbf{a}^\top \mathbf{x} - y\|^2$ (عنصر انحدار واحد).
- **المطلوب:** الهِسّية.
- **الحل:**

١. $\nabla = (\mathbf{a}^\top \mathbf{x} - y)\,\mathbf{a}^\top$.

٢. $H = \mathbf{a}\mathbf{a}^\top$ (رتبة 1).

٣. شبه موجبة $\Rightarrow$ محدّبة، لكن مفردة (بُعد بلا تقوّس على العمودي على $\mathbf{a}$). ■

- **النتيجة:** $H = \mathbf{a}\mathbf{a}^\top$ — رتبة 1.
- **الربط بالذكاء الاصطناعي:** «تقوّس عيّنة واحدة» رتبة-1؛ مكدّس على n عيّنات يعطي $H = \sum \mathbf{a}_i\mathbf{a}_i^\top = X^\top X$ — مصفوفة الغرام المعروفة.

مثال (3.9-15).

- **المعطيات:** $L(\mathbf{w}) = -\sum_i [y_i \ln \hat{y}_i + (1-y_i)\ln(1-\hat{y}_i)]$ للوجستية بمعامل واحد $\hat{y} = \sigma(wx)$.
- **المطلوب:** L'' على السلم، ثم الهِسّية لمعامل متعدّد.
- **الحل:**

١. $L' = (\hat{y} - y)x$، $L'' = \hat{y}(1-\hat{y})x^2 \geq 0$.

٢. متعدّد: $H = X^\top \mathrm{diag}(\hat{y}_i(1-\hat{y}_i))X \succeq 0$.

٣. الخسارة اللوجستية محدّبة في المعاملات. ■

- **النتيجة:** $H = X^\top D X$ — «غرام موزون».

- **الربط بالذكاء الاصطناعي:** هذه هي حجة «لماذا يعمل الانحدار اللوجستي بمحسّن بسيط»: محدّبة، هِسّية موجبة نصفياً، والوزن D يشبه «تشويش برنولي» — كل أدوات التقوّس هنا من هذا الفصل.

النظرية

dir="ltr"> <div

Chain rule, (matrix form). For $\mathbf{x} \xrightarrow{f} \mathbf{u} \xrightarrow{g} \mathbf{y}$ with compatible dimensions:

$$J_{g\circ f}(\mathbf{x}) = J_g(\mathbf{f}(\mathbf{x}))\cdot J_f(\mathbf{x}).$$

$$J_{g\circ f} = J_g\, J_f \tag{3.9}$$

الصيغ الجاهزة الأكثر استخداماً (سلمية L، متجهات):

التركيب	التدرّج $\nabla_{\mathbf{x}} L$
$L = f(\mathbf{u})$، $\mathbf{u} = A\mathbf{x}$	$A^\top \nabla_{\mathbf{u}} f$
$L = f(\mathbf{u})$، $\mathbf{u} = g(\mathbf{x})$ عنصرية	$\nabla_{\mathbf{u}} f \odot g'(\mathbf{x})$
$L = \|\mathbf{u}\|^2$، $\mathbf{u} = A\mathbf{x} - \mathbf{b}$	$2A^\top(A\mathbf{x} - \mathbf{b})$

$$\nabla_{\mathbf{x}} \big\|A\mathbf{x} - \mathbf{b}\big\|^2 = 2A^\top(A\mathbf{x} - \mathbf{b}) \tag{4.9}$$

برهان (4.9)

١. $J_u = A \implies \mathbf{u} = A\mathbf{x} - \mathbf{b}$ (مثال 9.2-11).

٢. $\nabla_u \|\mathbf{u}\|^2 = 2\mathbf{u}^\top$.

٣. السلسلة: $2\mathbf{u}^\top A = 2A^\top(A\mathbf{x} - \mathbf{b})$. ■

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
$J_{g\circ f} = J_f J_g$	ترتيب معكوس؛ الأبعاد لا تطابق	«الخارجي أولاً»: $J_g J_f$
نسيان النقل $A^\top$ عند الرجوع	«مرور أمامي بـ A، عكسي بـ $A^\top$»	القاعدة الذهبية
استخدام $J^\top$ عوضاً عن ∇ في السلم	السلم صفّ؛ J عمودي في بعض النصوص	ثبّت اصطلاحاً واحداً في كل الفصل
ضرب قطرية بعمود بترتيب خاطئ	$\mathrm{diag}(v)\mathbf{u} = \mathbf{u} \odot \mathbf{v}$	الضرب العنصري اختزال للقطرية

أمثلة محلولة على السلسلة المصفوفية (15 مثالاً)

مثال (4.9-1).

- **المعطيات:** $L = \|\mathbf{u}\|^2$، $\mathbf{u} = A\mathbf{x}$، $A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$، $\mathbf{x} = (1, 1)^\top$.
- **المطلوب:** $\nabla_{\mathbf{x}} L$ بـ (4.9).
- **الحل:**

١. $\mathbf{u} = (3, 1)$؛ $\|\mathbf{u}\|^2 = 10$.

٢. $2A^\top \mathbf{u} = 2\begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}\begin{pmatrix} 3 \\ 1 \end{pmatrix} = (6, 14)^\top$. ■

- **النتيجة:** $(6, 14)^\top$.
- **الربط بالذكاء الاصطناعي:** هذه «خطوة SGD في انحدار ريدج بوجه أوزان عام؛ لاحظ النقل — النسيان خطأ التنفيذ الأول في backprop اليدوي.

مثال (4.9-2).

- **المعطيات:** $L = \mathbf{c}^\top \mathbf{u}$، $\mathbf{u} = g(\mathbf{x})$ عنصرية.
- **المطلوب:** $\nabla_{\mathbf{x}} L$.
- **الحل:**

١. $J_u = \mathrm{diag}(g'(\mathbf{x}))$.

٢. $\nabla = \mathbf{c}^\top \mathrm{diag}(g') = (\mathbf{c} \odot g'(\mathbf{x}))^\top$. ■

- **النتيجة:** ضرب عنصري.
- **الربط بالذكاء الاصطناعي:** طبقة خطية «مقنّعة» بوزن ثابت $\mathbf{c}$؛ الضرب العنصري هو أرخص عمليات الـ backprop — $O(n)$.

مثال (9.4-3).

- **المعطيات:** شبكتان خطيتان متتاليتان: $\mathbf{u} = V\mathbf{x}$، $\mathbf{y} = W\mathbf{u}$، خسارة $\|\mathbf{y} - \mathbf{t}\|^2$.
- **المطلوب:** التدرّجين ∇_W و ∇_V (تجميع).
- **الحل:**

١. $\mathbf{r} = WV\mathbf{x} - \mathbf{t}$ (بقايا).

٢. $\nabla_W = 2\mathbf{r}(V\mathbf{x})^\top$.

٣. $\nabla_V = 2W^\top \mathbf{r}\,\mathbf{x}^\top$. ■

- **النتيجة:** «خطأ × مدخل الطبقة» لكل طبقة.
- **الربط بالذكاء الاصطناعي:** هذا backprop عملي بمعادلتين: كل تحديث يلزمه فقط البقايا ومدخل الطبقة — مبدأ «إعادة استخدام الوسطيات» الذي يجعل التدريب ممكناً.

مثال (9.4-4).

- **المعطيات:** $\mathbf{u} = \sigma(V\mathbf{x})$ (سيجمويد عنصري)، ثم $\mathbf{y} = W\mathbf{u}$، و $L = \|\mathbf{y} - \mathbf{t}\|^2$.
- **المطلوب:** ∇_V الكامل.
- **الحل:**

١. بقايا الطبقة الوسطى: $\boldsymbol{\delta} = 2W^\top(\mathbf{y} - \mathbf{t})$.

٢. مضاعفة بالتدرّج المحلي: $\boldsymbol{\delta} \odot \sigma'(\mathbf{z})$ حيث $\mathbf{z} = V\mathbf{x}$، و $\sigma' = \sigma(1 - \sigma)$.

٣. $\nabla_V = (\boldsymbol{\delta} \odot \sigma'(\mathbf{z}))\,\mathbf{x}^\top$. ■

- **النتيجة:** «خطأ راجع × تدرّج تنشيط × مدخل».
- **الربط بالذكاء الاصطناعي:** هذه هي الصيغة المتعلمة في كل كتب الشبكات؛ عامل $\sigma' \le \frac{1}{4}$ هو مصدر التلاشي المذكور سابقاً.

مثال (9.4-5).

- **المعطيات:** $L = \frac{1}{2}\|A\mathbf{x} - \mathbf{b}\|^2$ مع $\frac{1}{2}$.
- **المطلوب:** التدرّج وحلّ الصفر.
- **الحل:**

١. $\nabla = A^\top(A\mathbf{x} - \mathbf{b})$ (النصف ألغى الـ 2).

٢. الصفر: المعادلات الطبيعية $A^\top A\mathbf{x} = A^\top\mathbf{b}$.

٣. إن كانت A رتبة كاملة: $\mathbf{x}^* = (A^\top A)^{-1}A^\top\mathbf{b}$. ■

- **النتيجة:** حلّ المربعات الصغرى.

- **الربط بالذكاء الاصطناعي:** $A^\top A$ ظهرت في فصل 6 بحساب شرطها κ^2 — هنا نرى من أين تأتي أصلاً: من تربيع الخسارة.

مثال (٩.٤-6).

- **المعطيات:** $L = \operatorname{tr}(X^\top XW)$.
- **المطلوب:** ∇_W.
- **الحل:**

١. $\operatorname{tr}(X^\top XW) = \operatorname{tr}(WX^\top X)$ (دورية الأثر).

٢. بالتمايز: $\nabla_W = X^\top X$. ■

- **النتيجة:** $X^\top X$ — مصفوفة الغرام.

- **الربط بالذكاء الاصطناعي:** مصفوفة الغرام أساس «تناسق الأسلوب» في transfer style neural (غرام الأنماط) و PCA (التباين المشترك).

مثال (٩.٤-7).

- **المعطيات:** $L = \operatorname{tr}(AX)$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $\operatorname{tr}(AX) = \sum_{i,j} A_{ji}X_{ij}$.

٢. $\nabla_X = A^\top$. ■

- **النتيجة:** النقل فقط.

- **الربط بالذكاء الاصطناعي:** «مشتقّ الأثر هو النقل» — قاعدة أثرية أولى تُبنى عليها كل القواعد المصفوفية السريعة في الأوراق.

مثال (٩.٤-8).

- **المعطيات:** $L = \ln\det X$ (X موجبة التعريف).
- **المطلوب:** ∇_X.
- **الحل:**

١. $d(\ln\det X) = \operatorname{tr}(X^{-1}dX)$.

٢. $\nabla_X = X^{-1}$ (بالتماثل). ■

- **النتيجة:** X^{-1}.

- **الربط بالذكاء الاصطناعي:** «log-det» «barrier» في الأمثلية الداخلية و GPs: عقوبة على انكماش التباينات — تدرّجها هو المعكوس نفسه.

مثال (9-4.9).

- **المعطيات:** $L = \mathbf{x}^\top A\mathbf{x}$ عامّة (غير متماثلة).
- **المطلوب:** ∇ وإشكالية الجزء المضاد للتماثل.
- **الحل:**

١. $\nabla = \mathbf{x}^\top(A + A^\top)$.

٢. الجزء المضاد للتماثل يختفي (لأنّ $\mathbf{x}^\top M\mathbf{x} = 0$ لـ M مضادة للتماثل).

٣. عملياً نستبدل A بجزئها المتماثل. ■

- **النتيجة:** التدرّج «يرى» الجزء المتماثل فقط.

- **الربط بالذكاء الاصطناعي:** مصفوفات أوزان غير متكافئة الشكل؛ التدرّجات تقيس أثر الجزء المتماثل — معلومة توفّر حسابات زائدة.

مثال (10-4.9).

- **المعطيات:** $L = \|\mathbf{u}\|_2$، $\mathbf{u} \neq 0$، $\mathbf{u} = g(\mathbf{x})$.
- **المطلوب:** $\nabla_{\mathbf{x}} L$ وتحليلها عند $\mathbf{u} \to 0$.
- **الحل:**

١. $\nabla_u = \frac{\mathbf{u}^\top}{\|\mathbf{u}\|}$.

٢. بالسلسلة: $\frac{\mathbf{u}^\top}{\|\mathbf{u}\|} J_g$.

٣. عند $\mathbf{u} = 0$: غير قابلة للاشتقاق (شوكة). ■

- **النتيجة:** اتجاه الوحدة — بلا معامل طول.

- **الربط بالذكاء الاصطناعي:** لماذا نستخدم $\|u\|_2^2 + \epsilon$ بدل $\|u\|_2$ في الخسارات: نعومن الشوكة عند الصفر (نفس حجة الجذر في فصل 7).

مثال (9.4-11).

- **المعطيات:** $L = (\mathbf{w}^\top \mathbf{x}_i - y_i)^2$ لعيّنة واحدة، ثم المجموع على العيّنات.
- **المطلوب:** التدرّج الكلي.
- **الحل:**

١. عيّنة: $2(\mathbf{w}^\top \mathbf{x}_i - y_i)\mathbf{x}_i^\top$.

٢. المجموع: $2X^\top(X\mathbf{w} - \mathbf{y})$ حيث صفوف X هي $\mathbf{x}_i^\top$. ■

- **النتيجة:** $2X^\top(X\mathbf{w} - \mathbf{y})$.
- **الربط بالذكاء الاصطناعي:** «جمع التدرّجات عبر العيّنات = مصفوفة البيانات» — gradient batch يكتب بهذا السطر الواحد.

مثال (9.4-12).

- **المعطيات:** $L = \frac{1}{2}\|\mathbf{w}\|^2 + \lambda \max(0, 1 - y\,\mathbf{w}^\top \mathbf{x})$ (خسارة مفصلية SVM بعينة).
- **المطلوب:** subgradient.
- **الحل:**

١. إن $y\mathbf{w}^\top \mathbf{x} \geq 1$: $\nabla = \mathbf{w}^\top$.

٢. إن $y\mathbf{w}^\top \mathbf{x} < 1$: $\mathbf{w}^\top - \lambda y \mathbf{x}^\top$.

٣. الحدّية: مجموعة كاملة بين الاثنين. ■

- **النتيجة:** $\mathbf{w}^\top - \lambda y \mathbf{x}^\top \mathbb{1}[y\mathbf{w}^\top \mathbf{x} < 1]$.
- **الربط بالذكاء الاصطناعي:** SVM بـ Pegasos: تدرّج يُصحّح فقط «الانتهاكات» — نفس منطق ReLU: أبواب تفتح عند الحاجة.

مثال (9.4-13).

- **المعطيات:** $L = \text{softmax}(\mathbf{z})_k$، $\mathbf{z} = W\mathbf{x}$.
- **المطلوب:** ∇_W لخرج واحد.
- **الحل:**

١. $\nabla_z L = s \odot (\mathbf{e}_k - s)$ (مثال 9.6-3).

٢. بالسلسلة: $\nabla_W = (s \odot (\mathbf{e}_k - s))\,\mathbf{x}^\top$. ■

- **النتيجة:** «إشارة خطأ مصنّف × مدخل».
- **الربط بالذكاء الاصطناعي:** تصنيف الأحرف/الأصناف بطبقة softmax خطية: تحديث الصف k يتناسب مع «الفرق بين الحقيقة والتوقّع».

مثال (9.4-14).

- **المعطيات:** تدفّق عميق: $\mathbf{a}_{k+1} = \phi(W_k\mathbf{a}_k + \mathbf{b}_k)$، $k = 1..K$، خسارة $L(\mathbf{a}_{K+1})$.
- **المطلوب:** صيغة الانتشار العكسي الكاملة.
- **الحل:**

١. عرّف إشارة الطبقة $\boldsymbol{\delta}_k = \frac{\partial L}{\partial \mathbf{z}_k}$ حيث $\mathbf{z}_k = W_k\mathbf{a}_k + \mathbf{b}_k$.

٢. الاستقرار الخلفي: $\boldsymbol{\delta}_k = W_{k+1}^{\top}\boldsymbol{\delta}_{k+1} \odot \phi'(\mathbf{z}_k)$.

٣. التدرّجات: $\nabla_{W_k} = \boldsymbol{\delta}_k\mathbf{a}_k^{\top}$، $\nabla_{\mathbf{b}_k} = \boldsymbol{\delta}_k$. ■

- **النتيجة:** ثلاث معادلات تُشغّل كل التعلم العميق.
- **الربط بالذكاء الاصطناعي:** هذه هي المعادلات التي تنفّذها autograd؛ كل شيء في الفصلين 7–9 كان تمهيداً لها.

مثال (9.4-15).

- **المعطيات:** $L = \|A\mathbf{x} - \mathbf{b}\|_1$ (خسارة Huber خامسية — L1 للأخطاء).
- **المطلوب:** subgradient بالسلسلة المصفوفية.
- **الحل:**

١. $\nabla_u\|\mathbf{u}\|_1 = \operatorname{sgn}(\mathbf{u})$ (عنصرياً، عند الأصفار $[-1, 1]$).

٢. $\nabla_{\mathbf{x}} = \operatorname{sgn}(A\mathbf{x} - \mathbf{b})^{\top}A$. ■

- **النتيجة:** إشارة البقايا × مصفوفة التصميم.
- **الربط بالذكاء الاصطناعي:** LAD-regression (أقل انحراف مطلق) — متين للقيم الشاذة؛ التنفيذ يستخدم median/quantile أو smooth approximation (Huber).

قواعد الأثر والتفاضل

$f(X)$ الدالة	$\nabla_X f$	الشرط
$\operatorname{tr}(X)$	I	—
$\operatorname{tr}(AX)$	$A^{\top}$	—
$\operatorname{tr}(X^{\top}AX)$	$(A + A^{\top})X$	—
$\ln\det X$	X^{-1}	$X \succ 0$
$\det X$	$\det(X)\,X^{-1}$	X قابلة للعكس
$\operatorname{tr}(X^{-1}A)$	$-X^{-1}A^{\top}X^{-1}$	—

$$\nabla_X \ln\det X = X^{-1}, \qquad \nabla_X \det X = \det(X)\,X^{-1} \tag{5.9}$$

برهان نموذجي — $\ln\det$:

للمقاربة $X \to X + \epsilon E$:

$$\ln\det(X+\epsilon E) = \ln\det X + \ln\det(I + \epsilon X^{-1}E) = \ln\det X + \epsilon\,\mathrm{tr}(X^{-1}E) + O(\epsilon^2),$$

فالمشتقّ الاتجاهي في E هو $\mathrm{tr}(X^{-1}E)$، ومنه (5.9). ■

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
$\nabla \mathrm{tr}(AX) = A$	نسيان النقل بالاصطلاح	$A^\top$ (باصطلاح التدرّج الصفّي)
نسيان شرط موجبة التعريف في $\ln\det$	اللوغاريتم غير معرّف للمحدّد السالب	قيّد $X \succ 0$
مشتقّ $\det$ للأبعاد الكبيرة كـ «حساسية محدّد» خطّية	غير خطيّ تماماً	(5.9) — معكوس × محدّد
الخلط بين $d\,\mathrm{tr}$ و $d(\cdot)$ المقطري	التفاضل المصفوفي يخضع لدورة الأثر	اكتب $df = \mathrm{tr}(G^\top dX)$ ثم استخرج G

أمثلة محلولة على مشتقّات العمليات المصفوفية (15 مثالاً)

مثال (5.9-1).

- **المعطيات:** $f(X) = \mathrm{tr}(X)$ لـ $X \in \mathbb{R}^{n\times n}$.
- **المطلوب:** $\nabla_X f$.
- **الحل:**

١. $df = \sum_i dX_{ii} = \mathrm{tr}(I\,dX)$.

٢. $\nabla = I$. ■

- **النتيجة:** I.
- **الربط بالذكاء الاصطناعي:** «الأثر» يجمع القطريات؛ تدرّجه موحّد — أساس متابعة «حجم إجمالي» في مقياسات المصفوفات.

مثال (5.9-2).

- **المعطيات:** $f(X) = \mathrm{tr}(A^\top X)$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $f = \langle A, X\rangle_F$ (الجداء الداخلي الفروبيوس).

٢. $\nabla = A$. ■

- **النتيجة:** A — «مشتقّ الجداء الداخلي هو الطرف الآخر».
- **الربط بالذكاء الاصطناعي:** خسارة «مطابقة مصفوفتين» (مقارنة أنماط) تدرّجها هو المقارَن — نفس منطق $(\hat{y} - y)$ في القياسي.

مثال (9.5-3).

- **المعطيات:** $f(X) = \operatorname{tr}(X^\top X) = \|X\|_F^2$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $df = 2\operatorname{tr}(X^\top dX)$.

٢. $\nabla = 2X$. ■

- **النتيجة:** $2X$ — نظير $2x$ للمتجه.

- **الربط بالذكاء الاصطناعي:** تنظيم الوزن (weight decay) لكل طبقة مصفوفية: تدرّجه يتناسب مع الأوزان نفسها — لهذا weight decay يعمل مثل «انسحاب نحو الصفر».

مثال (9.5-4).

- **المعطيات:** $f(X) = \operatorname{tr}(X^\top A X)$ مع A متماثلة.
- **المطلوب:** ∇_X.
- **الحل:**

١. $df = \operatorname{tr}(dX^\top AX + X^\top A\,dX) = \operatorname{tr}\big((AX + AX)^\top dX\big)$... بترتيب دقيق: $df = 2\operatorname{tr}((AX)^\top dX)$.

٢. $\nabla = 2AX$. ■

- **النتيجة:** $2AX$.

- **الربط بالذكاء الاصطناعي:** «تدرّج الطاقة التربيعية المصفوفية» — نمط القوة الخطّية في أنظمة المربعات الصغرى ثنائية الأبعاد (مصفوفة معاملات بدل متجه).

مثال (9.5-5).

- **المعطيات:** $f(X) = \ln\det X$ على $X \succ 0$، عند $X = \operatorname{diag}(1, 2)$.
- **المطلوب:** ∇ وقيمته.
- **الحل:**

١. $\nabla = X^{-1} = \operatorname{diag}(1, \tfrac{1}{2})$.

٢. $f = \ln 2 \approx 0.693$. ■

- **النتيجة:** التدرّج القطري هو معكوس القيم.

- **الربط بالذكاء الاصطناعي:** «حاجز log-det» يعاقب مصفوفات التباين المنكمشة بعكسها — في GPs يضمن بقاء النواة موجبة التعريف أثناء التحسين.

مثال (5.9-6).

- **المعطيات:** $f(X) = \det X$ لعناصر 2×2.
- **المطلوب:** ∇_X والتحقق من (5.9).
- **الحل:**

١. $\det X = x_{11}x_{22} - x_{12}x_{21}$.

٢. $\nabla = \begin{bmatrix} x_{22} & -x_{21} \\ -x_{12} & x_{11} \end{bmatrix}$.

٣. وهذا هو $\det(X)X^{-1}$ فعلاً (بالمرافق). ■

- **النتيجة:** مصفوفة المرافقة.
- **الربط بالذكاء الاصطناعي:** «مشتقّ المحدّد = المرافق»؛ تفد في تدفّقات طبيعية صغيرة حيث يُحسب أثر تغيّر المحدّد على الكثافة.

مثال (5.9-7).

- **المعطيات:** $f(X) = \operatorname{tr}(X^{-1}A)$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $d(X^{-1}) = -X^{-1}(dX)X^{-1}$.

٢. $df = -\operatorname{tr}(X^{-1}(dX)X^{-1}A) = -\operatorname{tr}(X^{-1}AX^{-1}dX)$.

٣. $\nabla = -X^{-1}A^{\top}X^{-1}$ (ومتماثلة إذا كانت A كذلك). ■

- **النتيجة:** كما في الجدول.
- **الربط بالذكاء الاصطناعي:** تحسين «أثر المعكوس» يظهر في تجميع Fisher المعلوماتي — عقوبات كربوفي المنطقية.

مثال (5.9-8).

- **المعطيات:** $f(X) = \|AX - B\|_F^2$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $df = 2\operatorname{tr}\big((AX - B)^{\top}A\,dX\big)$.

٢. $\nabla = 2A^{\top}(AX - B)$. ■

- **النتيجة:** نظير (4.9) بالمصفوفات.
- **الربط بالذكاء الاصطناعي:** «تحليل القيم المفردة المصغّر» (rank-constrained) وحلّ Procrustes — مشاكل معاملات مصفوفية كاملة (matrix factorization) في أنظمة التوصية).

مثال (9-5.9).

- **المعطيات:** $f(X) = \lambda_{\max}(X)$ للعدد الطيفي عند نقطة القيمة العظمى بسيطة.
- **المطلوب:** ∇ الاتجاهي.
- **الحل:**

١. لقيمة ذاتية بسيطة: $\nabla = \mathbf{v}\mathbf{v}^\top$ حيث $\mathbf{v}$ المتجه الذاتي الموحّد.

٢. خارجها: غير قابلة للاشتقاق (زوايا عند تقاطع قيم). ■

- **النتيجة:** إسقاط رتبة-1 على المتجه الذاتي القائد.

• **الربط بالذكاء الاصطناعي:** «شحاذة شكل الحوض»: sharpness تقاس بـ $\lambda_{\max}(H)$؛ تدرّجها يقود SAM — تخفيف اتجاه المتجه الذاتي الأكبر.

مثال (10-5.9).

- **المعطيات:** $f(\mathbf{x}) = \mathbf{x}^\top H\mathbf{x}$ مع H هِسّية (متماثلة).
- **المطلوب:** الاستقراء الثاني بمنتج Hessian-vector.
- **الحل:**

١. $\nabla = 2(H\mathbf{x})^\top$.

٢. منتج HV: $H\mathbf{v}$ يُحسب بفرق منتهٍ على التدرّج: $H\mathbf{v} \to \frac{\nabla f(\mathbf{x}+\epsilon\mathbf{v}) - \nabla f(\mathbf{x})}{\epsilon}$.

٣. تكلفة: مروران فقط لا $O(n^2)$. ■

- **النتيجة:** Hessian-vector في تكلفة تدرّج.

• **الربط بالذكاء الاصطناعي:** هذه الحيلة تجعل حساب $\lambda_{\max}(H)$ ممكناً للنماذج الضخمة (Lanczos/power iterations على المنتجات) — أساس قياس الشحاذة بدون بناء H.

مثال (11-5.9).

- **المعطيات:** $f(X) = \operatorname{tr}(X)$ مع قيد X متماثلة.
- **المطلوب:** التدرّج على المشعب المتماثل.
- **الحل:**

١. dX متماثل $\Longrightarrow$ فقط الجزء المتماثل من G يهمّ.

٢. إسقاط: $\nabla_{\text{sym}} = \frac{G+G^\top}{2} = I$. ■

- **النتيجة:** الوحدة مرة أخرى (متماثلة أصلاً).

- **الربط بالذكاء الاصطناعي:** «الاشتقاق على مشعب» — بعض المعاملات متماثلة/متعامدة بنيوياً؛ التدرّج يُسقط على مسموح التحديث (Riemannian optimization).

مثال (9.5-12).

- **المعطيات:** $f(Q) = \text{tr}(Q^\top A Q)$ مع Q متعامدة.

- **المطلوب:** التدرّج على مجموعة التعامد (متعرّج).

- **الحل:**

١. تدرّج حرّ: $2AQ$.

٢. إسقاط مائل للتعامد: $G - AQQ^\top$... بالصيغة: $\nabla_{\mathcal{O}} = 2AQ - 2Q\,\text{sym}(Q^\top A Q)$.

٣. للحالة المتماثلة A: يبسط إلى $2[AQ - Q\,\text{diag}(Q^\top A Q)]$. ■

- **النتيجة:** اتجاهات «دورانية» صرفة.

- **الربط بالذكاء الاصطناعي:** PCA و weights: orthogonal التحديث دوراني على مشعب ستيفل — يحفظ التعامد بلا إعادة تكييف (no re-orthogonalization) كل خطوة.

مثال (9.5-13).

- **المعطيات:** $f(X) = \sum_i \lambda_i(X)$ = الأثر (مجموع القيم الذاتية).

- **المطلوب:** ∇.

- **الحل:**

١. $\text{tr}(X) = \sum \lambda_i$ (للمصفوفة المربعة).

٢. $\nabla = I$ — لا اعتماد على القيم الذاتية كائنات. ■

- **النتيجة:** الأثر «أعمى» عن أساس التحييد.

- **الربط بالذكاء الاصطناعي:** «ثبات دوراني»: المعايير المعتمدة على الأثر/القيم لا تتأثر بأساس — لهذا regularization الطيفي ثابت التدوير.

مثال (9.5-14).

- **المعطيات:** $f(\mathbf{x}) = \sqrt{\mathbf{x}^\top \mathbf{x} + \epsilon}$ (نُرم مستقرّة عددياً).
- **المطلوب:** ∇ وقارن مع $\|\mathbf{x}\|_2$.
- **الحل:**

١. $\nabla = \frac{\mathbf{x}^\top}{\sqrt{\mathbf{x}^\top \mathbf{x} + \epsilon}}$.

٢. عند $\mathbf{x} = 0$: التدرّج $0 = 0$ (بلا انفجار) — مختلفة عن $\|\mathbf{x}\|_2$ غير القابلة للاشتقاق. ■

- **النتيجة:** نسخة ناعمة بثابت ϵ.
- **الربط بالذكاء الاصطناعي:** هذا بالضبط مقام LayerNorm $(\sqrt{\sigma^2 + \epsilon})$؛ ϵ يشتري قابلية الاشتقاق في الصفر بأدنى تشويه.

مثال (5.9-15).

- **المعطيات:** $f(X) = \ln\det(X) + \operatorname{tr}(X^{-1}S)$ (دالة الاحتمال الغاوسي المركّزة، مقياس S).
- **المطلوب:** ∇_X ونقطة المثل بالتعويض.
- **الحل:**

١. من (5.9) والمثال 5.9-7: $\nabla = X^{-1} - X^{-1}SX^{-1}$.

٢. الصفر: $X = S$. ■

- **النتيجة:** «تقدير التباين الأعظم» هو S — المشتقّ يؤكد الشهرة.
- **الربط بالذكاء الاصطناعي:** تعلّم calibration: multi-variate / process Gaussian المعادلة نفسها تضبط مصفوفات الدقّة (precision) في نماذج الاحتمال العميقة.

النظرية — يعقوبية softmax

dir="ltr"> <div

Theorem 6.9 (Softmax Jacobian). For $\mathbf{s} = \operatorname{softmax}(\mathbf{z})$:

$$\frac{\partial s_i}{\partial z_j} = s_i(\delta_{ij} - s_j).$$

$$J_{\text{softmax}} = \operatorname{diag}(\mathbf{s}) - \mathbf{s}\,\mathbf{s}^\top \tag{6.9}$$

برهان (6.9).

١. $s_i = \dfrac{e^{z_i}}{S}$، $S = \sum_k e^{z_k}$.

٢. $\dfrac{\partial s_i}{\partial z_j} = \dfrac{\delta_{ij} e^{z_i} S - e^{z_i} e^{z_j}}{S^2} = s_i \delta_{ij} - s_i s_j$. ■

النتيجة الجملية (للاستخدام المباشر): لخسارة انتروبيا متقاطعة $L = -\sum_k y_k \ln s_k$ مع أهداف one-hot:

$$\nabla_{\mathbf{z}} L = \mathbf{s} - \mathbf{y} \tag{7.9}$$

— «التوقّع ناقص الحقيقة» — أنظف تدرّج في التعلم الآلي كله.

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
كتابة $J = \operatorname{diag}(\mathbf{s})$ فقط	نسيان ترابط الصفوف (المجموع = 1)	(6.9) يضمّن الناقص $ss^\top$
حساب تدرّج softmax ثم cross-entropy منفصلين	إهدار وحساسيات أضعف	(7.9) مباشرة — أجمعهما دائماً
نسيان أنّ (6.9) شبه موجبة بالضبط	صفوف J تجمع إلى 0 (قيمة ذاتية صفرية)	softmax ثابت بالإزاحة — إزالة درجة حرية
«∇ على W = تدرّج على $\mathbf{z}$»	بينهما سلسلة واحدة	$\nabla_W = (\mathbf{s} - \mathbf{y})\mathbf{x}^\top$

أمثلة محلولة على التطبيقات (15 مثالاً)

مثال (6.9-1).

- **المعطيات:** $\mathbf{z} = (2, 1, 0)$.
- **المطلوب:** $\mathbf{s} = \operatorname{softmax}(\mathbf{z})$ و J من (6.9) عند الخلية $(1, 1)$.
- **الحل:**

١. $s = (e^2, e^1, 1)/(e^2 + e + 1) \approx (0.665,\ 0.245,\ 0.090)$.

٢. $J_{11} = s_1(1 - s_1) = 0.665 \times 0.335 \approx 0.2227$.

٣. $J_{12} = -s_1 s_2 \approx -0.163$. ■

- **النتيجة:** قيم كما هو.
- **الربط بالذكاء الاصطناعي:** أرقام «معدّل التدفق» الحقيقية لطبقة إخراج مصنّف، القطري دائماً الأكبر — الإشارات الموجبة على الذات.

مثال (6.9-2).

- **المعطيات:** $L = -\ln s_2$ مع $\mathbf{s}$ من المثال السابق (y = الصنف 2).
- **المطلوب:** $\nabla_{\mathbf{z}} L$ من (7.9).
- **الحل:**

١. $\mathbf{y} = (0, 1, 0)$.

٢. $\mathbf{s} - \mathbf{y} \approx (0.665, -0.755, 0.090)$. ■

- **النتيجة:** دفعة نحو الصنف الصحيح بعكس الإشارة.

- **الربط بالذكاء الاصطناعي:** «كل الصفوف تنقص ما عدا الحقيقي» — هذا السطر يُطبع في سجلات التدريب كل خطوة: توقّع ناقص حقيقة.

مثال (9.6-3).

- **المعطيات:** هدف واحد-hot عامّ $\mathbf{y}$.

- **المطلوب:** اشتقّ (9.7) من (9.6).

- **الحل:**

١. $\nabla_z L = -\sum_k y_k \frac{1}{s_k} \frac{\partial s_k}{\partial z_j}$.

٢. بالتعويض: $-\sum_k y_k(\delta_{kj} - s_k) = -y_j + \underbrace{\sum_k y_k}_{1} s_j$.

٣. النتيجة $s_j - y_j$. ■

- **النتيجة:** (9.7) عامّة.

- **الربط بالذكاء الاصطناعي:** «الاختزال» الذي يوفر حساب $\frac{1}{s_k}$ (انفجار محتمل) — الدمج الرياضي بدل الحساب المنفصل يقتل مشكلة العددية.

مثال (9.6-4).

- **المعطيات:** انحدار خطّي ببيانات $X \in \mathbb{R}^{n \times d}$.

- **المطلوب:** ∇_w لخسارة MSE وحلّها المغلق.

- **الحل:**

١. $L = \frac{1}{n}\|X\mathbf{w} - \mathbf{y}\|^2$؛ $\nabla = \frac{2}{n} X^\top (X\mathbf{w} - \mathbf{y})$.

٢. الصفر: $X^\top X \mathbf{w} = X^\top \mathbf{y}$.

٣. $\mathbf{w}^* = (X^\top X)^{-1} X^\top \mathbf{y}$ (رتبة كاملة). ■

- **النتيجة:** المعادلة الطبيعية.

- **الربط بالذكاء الاصطناعي:** «الحل المغلق المرجعي» الذي نقيس عليه كل المحسّنات التدريجية؛ وبشكله $X^\top X$ يذكّرنا بشرط κ^2 من فصل 6.

مثال (9.6-5).

- **المعطيات:** انحدار ريدج: $L = \frac{1}{n}\|X\mathbf{w} - \mathbf{y}\|^2 + \lambda\|\mathbf{w}\|^2$.
- **المطلوب:** الحل المغلق.
- **الحل:**

١. $\nabla = \frac{2}{n}X^\top(X\mathbf{w} - \mathbf{y}) + 2\lambda\mathbf{w}$.

٢. $\mathbf{w}^* = (X^\top X + n\lambda I)^{-1}X^\top\mathbf{y}$. ■

- **النتيجة:** إضافة $n\lambda I$ تجعل المعكوس ممكناً دائماً.

- **الربط بالذكاء الاصطناعي:** «ريج = إصلاح المفردة»: الفصل 6 كشف أنّ $\kappa(A^\top A)$ يكاد يكون مربّعاً؛ إزاحة القطر تُخفض الشرط وتضمن وجوداً.

مثال (9.6-6).

- **المعطيات:** الانحدار اللوجستي متعدد الصفوف: $\hat{\mathbf{y}} = \text{softmax}(W\mathbf{x})$، خسارة متقاطعة.
- **المطلوب:** ∇_W لعينة واحدة.
- **الحل:**

١. من (9.7): $\nabla_z = (\hat{\mathbf{y}} - \mathbf{y})$.

٢. سلسلة: $\nabla_W = (\hat{\mathbf{y}} - \mathbf{y})\mathbf{x}^\top$. ■

- **النتيجة:** مصفوفة خارجية خطأ×مدخل.

- **الربط بالذكاء الاصطناعي:** هذه «الطبقة النهائية» لكل مصنّف؛ التحديث الصفّي: صفّ الحقيقة يرتفع وصفوف التوقّع الخاطئة تنخفض.

مثال (9.6-7).

- **المعطيات:** LayerNorm لعدد واحد: $g(\mathbf{x}) = \frac{\mathbf{x}-\mu\mathbf{1}}{\sqrt{\sigma^2+\epsilon}} \odot \boldsymbol{\gamma} + \boldsymbol{\beta}$.
- **المطلوب:** بنية اليعقوبية (دون تفصيل كامل).
- **الحل:**

١. ثلاث مسارات: عبر المقام (رتبة كاملة)، عبر μ (رتبة-1)، عبر σ^2 (رتبة-1).

٢. $J = J_{\text{مقام}} + J_\mu + J_{\sigma^2}$؛ كل مسار له عامل قياس.

٣. عملياً: backprop يجمع المسارات الثلاثة. ■

- **النتيجة:** يعقوبية مجموع ثلاث إسهامات.

- **الربط بالذكاء الاصطناعي:** هذا «الشتّاء الرياضي» الذي يفاجئ من يكتب LayerNorm يدوياً — المكتبات تختصره؛ المسارات الثلاثة هي أسباب أخطاء التدرّج الشائعة في التنفيذ المنزلي.

مثال (6.9-8).

- **المعطيات:** انتباه ذاتي لعنصر واحد: $\text{Attn}(\mathbf{q},\mathbf{K},\mathbf{V})=\sum_j \alpha_j \mathbf{v}_j$، $\alpha=\text{softmax}(\mathbf{q}^\top \mathbf{k}_j/\sqrt{d})$.
- **المطلوب:** صيغة تدرّج $\mathbf{q}$.
- **الحل:**

١. J_α من (6.9) بحجم n (عدد الرؤوس/السياق).

٢. $\nabla_q=\sum_j \frac{\partial L}{\partial \alpha_j}\cdot\frac{\partial \alpha_j}{\partial \mathbf{q}}=\sum_{j,l}\frac{\partial L}{\partial \alpha_j}J_{\alpha,jl}\frac{\mathbf{k}_l}{\sqrt{d}}$.

٣. شكل مصفوفي: $\nabla_{\mathbf{q}}=\frac{1}{\sqrt{d}}K^\top\left[J_\alpha^\top\frac{\partial L}{\partial \boldsymbol{\alpha}}\right]$. ■

- **النتيجة:** يعقوبية softmax داخل الانتباه.

• **الربط بالذكاء الاصطناعي:** «تراكب الانتباه» تحسبها flash-attention ضمنياً، بنية (6.9) نفسها، بالحجم الذي يفرض تحسينات الذاكرة.

مثال (6.9-9).

- **المعطيات:** $L=\frac{1}{2}\|W\|_F^2+\lambda\|WX-\mathbf{t}\|^2$.
- **المطلوب:** ∇_W.
- **الحل:**

١. $\nabla=\lambda\cdot 2(WX-\mathbf{t})X^\top+W$.

٢. قابلية حلّ خطي في W (محدّبة في W). ■

- **النتيجة:** $2\lambda(WX-\mathbf{t})X^\top+W$.

• **الربط بالذكاء الاصطناعي:** «اختناق عائد مشترك» بوجود المصفوفة الازدواجية؛ مشاكل معاملات كاملة تُحلّ خطيّاً بذلك الشكل — انحدار سجلات (logistic) بمعاملات بديلة.

مثال (6.9-10).

- **المعطيات:** $L=\|\text{diag}(\mathbf{s})-\mathbf{s}\mathbf{s}^\top\|_F$؟ بديلاً: احسب القيم الذاتية لـ (6.9).
- **المطلوب:** أثبت أنّ (6.9) شبه موجبة بقيمة ذاتية صفرية على $\mathbf{1}$.
- **الحل:**

١. $J\mathbf{1}=\mathbf{s}-\mathbf{s}(\mathbf{s}^\top\mathbf{1})=\mathbf{s}-\mathbf{s}=0$.

٢. لأيّ $\mathbf{v}$: $\mathbf{v}^\top J\mathbf{v} = \sum_i s_i v_i^2 - (\sum_i s_i v_i)^2 = \mathrm{Var}_s(v) \geq 0$.

٣. إذن $J \succeq 0$ مع نواة $\mathrm{span}(\mathbf{1})$. ■

- **النتيجة:** شبه موجبة، مفرّدة بدرجة.

- **الربط بالذكاء الاصطناعي:** softmax» لا يرى الإزاحة» — درجة حرية مفقودة؛ لهذا logits تُعالج بإزاحة عشوائية بأمان، ولماذا الدرجة الحرارة تُقارن بالأسّ فقط.

مثال (9.6-11).

- **المعطيات:** $L(\mathbf{w}) = \frac{1}{n}\sum_i \ln(1 + e^{-y_i \mathbf{w}^\top \mathbf{x}_i})$ $(y_i \in \{\pm 1\})$.

- **المطلوب:** التدرّج وقرنته بالصيغة ثنائية الصنف.

- **الحل:**

١. $\nabla = \frac{1}{n}\sum_i -\sigma(-y_i \mathbf{w}^\top \mathbf{x}_i)\, y_i \mathbf{x}_i^\top$.

٢. بصيغة $\{0,1\}$: $(\hat{y}_i - y_i)\mathbf{x}_i^\top$ — التان.

٣. متكافئان. ■

- **النتيجة:** $\frac{1}{n}\sum_i (\sigma(y_i w^\top x_i) - 1) y_i x_i^\top$.

- **الربط بالذكاء الاصطناعي:** صيغة ± 1 لطيفة في SVM-adjacent الأدبيات، صيغة $\{0,1\}$ في backprop — نفس الرياضيات بلغتين.

مثال (9.6-12).

- **المعطيات:** $L = \|\mathbf{g}\|^2$ حيث $\mathbf{g} = \nabla_{\mathbf{w}} f(\mathbf{w})$ (خسارة تدرّج-مربّع — هدف في SAM/bilevel).

- **المطلوب:** الهِسّية الظاهرة (Hessian-vector).

- **الحل:**

١. $\nabla_{\mathbf{w}} L = 2J_g^\top \mathbf{g} = 2H\,\nabla f$.

٢. «هِسّية × تدرّج» — يتطلب منتج HV.

٣. بالفروق على التدرّج: مروران إضافيان. ■

- **النتيجة:** $2H\nabla f$.

- **الربط بالذكاء الاصطناعي:** «تدرّج التدرّج» — محرّك محسّنات المستوى الثاني Newton) بلا تربيعات) وأهداف الشحاذة، إضافته تكلف مضاعفة وقت الدفعة.

مثال (9.6-13).

- **المعطيات:** Adam: $\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1-\beta_2)\mathbf{g}_t^2$ (عنصرياً) ثم $\Delta w = -\eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\epsilon}$.
- **المطلوب:** تفسير المقام بلغة الهِسّية القطرية التقريبية.
- **الحل:**

١. $\hat{v}_t \approx$ متوسط مربّعات التدرّج $\approx$ تقدير H_{ii} القطري (لنماذج محدّبة تقريباً).

٢. القسمة = تحديد مسبق قطري (preconditioning) — تقريب لطريقة نيوتن بقطرية فقط.

٣. التكلفة: ذاكرة ضعف الأوزان. ■

- **النتيجة:** Adam $\approx$ Newton قطري مبسّط بمعدّل صغير.
- **الربط بالذكاء الاصطناعي:** هذه قرنة نظريّة شائعة لنجاح Adam على أحواض ill-conditioned (فصل 6 وأمثلة 9.3-9): تعديل القيم الذاتية القطرية يدوياً.

مثال (9.6-14).

- **المعطيات:** $L = |\mathbf{w}^\top \mathbf{x} - y|$ بعيّنة واحدة، مدخل $\mathbf{x} \neq 0$.
- **المطلوب:** subgradient ونقاط «الشوكة».
- **الحل:**

١. $\nabla = \operatorname{sgn}(\mathbf{w}^\top \mathbf{x} - y)\, \mathbf{x}^\top$.

٢. عند $\mathbf{w}^\top \mathbf{x} = y$: مجموعة كاملة $\{\lambda \mathbf{x}^\top : |\lambda| \le 1\}$.

٣. شوكة على «المستوي العمودي على $\mathbf{x}$». ■

- **النتيجة:** subgradient متجه كامل.
- **الربط بالذكاء الاصطناعي:** انحدار LAD: «التوقّف عند أول بلوغ» — المستوى الجداري؛ لهذا L1 يصنع حلولاً على «حواف» الفضاء (تناثر هندسي).

مثال (9.6-15).

- **المعطيات:** شبكة من طبقتين بإخراج softmax: $\hat{\mathbf{y}} = \operatorname{softmax}(W_2 \operatorname{ReLU}(W_1 \mathbf{x}))$ وخسارة متقاطعة.
- **المطلوب:** التدرّج الكامل لـ W_1 بسطور معدودة.
- **الحل:**

١. $\boldsymbol{\delta}_2 = \hat{\mathbf{y}} - \mathbf{y}$ (من 7.9).

٢. $\boldsymbol{\delta}_1 = W_2^\top \boldsymbol{\delta}_2 \odot \mathbb{1}[\mathbf{z}_1 > 0]$ (قناع ReLU).

٣. $\nabla_{W_1} = \boldsymbol{\delta}_1 \mathbf{x}^\top$. ■

- **النتيجة:** ثلاثة أسطر — كل backprop.
- **الربط بالذكاء الاصطناعي:** هذا «أصغر مثال كامل» للانتشار العكسي عبر تنشيط غير خطي — كل شبكة حقيقية تكرار لهذه الأسطر بمقاييس ضخمة.

خيط الفصل

١. **اليعقوبية (1.9)** تعمّم المشتقّ: كل التدفق بين الطبقات يوصف بمصفوفة حساسيات.

٢. **الهِسّية (2.9)** تحوّل «شكل الحوض» إلى مصفوفة قيم ذاتية — والقيم الذاتية تحكم سرعة التقارب (جسر مباشر إلى فصل 6).

٣. **السلسلة (3.9)** تضاعف اليعقوبيات — والضرب المتكرر هو «نهر التلاشي/الانفجار».

٤. **القواعد الأثرية (5.9)** تسرّع كل الحساب: مشتقّ الأثر نقل، ومشتقّ log-det معكوس.

٥. **التطبيقات (6.9)** تعطينا «كنز الصيغ»: $\nabla L = \hat{y} - y$ للوجستياً، $J = \mathrm{diag}(s) - ss^\top$ لـsoftmax، و $\mathbf{w}^* = (X^\top X + \lambda I)^{-1} X^\top \mathbf{y}$ لريج.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
اليعقوبية	autograd بالكامل (فصل 36)
$H \succeq 0$	براهين محدّبية الخسارة (فصل 40)
$J = \mathrm{diag}(s) - ss^\top$	تصنيفات softmax النهائية
$2A^\top(Ax - b)$	المحسّنات الخطّية المربعة
Hessian-vector	SAM وشحاذة النماذج الضخمة
إسقاط التدرّج	مشابك التعامد (منها ortho) attention

١. احسب اليعقوبية لـ $\mathbf{f}(x, y) = (xy,\ x/y)$، وحدّد أين تنشذ.

٢. أثبت أنّ $J_{A\mathbf{x}} = A$ و $J_{A\mathbf{x}+\mathbf{b}} = A$ (لا تعتمد على $\mathbf{b}$).

٣. احسب $\nabla_{\mathbf{x}} \mathbf{x}^\top A \mathbf{x}$ لـ $A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}$، وتحقّق من صيغة $A + A^\top$.

٤. أوجد اليعقوبية لـ $\mathbf{f}(\mathbf{x}) = \mathbf{x}/\|\mathbf{x}\|_1$ (عند $\mathbf{x} \neq 0$، أولًا فرديًا).

٥. احسب الهِسّية لـ $f(x, y) = e^{x^2 + y^2}$ وحدّد مناطق التقوّس.

٦. طبّق اختبار المشتقّ الثاني للدالة $f(x, y) = x^2 + y^2 - xy + x$.

٧. أوجد نقاط السرج للدالة $f(x, y) = x^3 - 3xy^2$ (دالة مونج-أمبير) وتصنيف النقطة الحرجة الوحيدة.

٨. اشتقّ $\nabla_X \mathrm{tr}(X^2)$ ثم $\nabla_X \mathrm{tr}(X^k)$ (استقراءً).

٩. أثبت من التفاضل أنّ $\nabla_X \|X\|_F = \frac{X}{\|X\|_F}$ عند $X \neq 0$.

١٠. احسب يعقوبية softplus المتجهة $\mathrm{softplus}(\mathbf{z})$ وقارنها بسيجمويد (هي نفسها!).

١١. أثبت أنّ صفوف J_{softmax} تجمع إلى الصفر، وفسّر بدلالة «ثبات الإزاحة».

١٢. احسب ∇_W لخسارة $-\ln(\mathrm{softmax}(W\mathbf{x})_2)$ وأوجد قيمتها عند $\mathbf{x} = (1, 1)$، $W = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$.

١٣. أثبت أنّ خسارة MSE لريج مع $\lambda > 0$ لها صغرى عالمية وحيدة حتى لو كانت X مفردة.

١٤. طبّق قاعدة السلسلة لثلاث دوال: $\mathbf{x} \to A\mathbf{x} \to \mathrm{ReLU} \to B\cdot \to \|\cdot\|^2$ واكتب التدرّج النهائي.

١٥. أثبت متباينة التدرّج: $\|f(\mathbf{y}) - f(\mathbf{x})\| \le \sup_t \|J_f(\mathbf{x} + t(\mathbf{y}-\mathbf{x}))\| \, \|\mathbf{y}-\mathbf{x}\|$ (بتكامل أو MVT مصفوفي).

١٦. احسب Hessian-vector product لـ $f(\mathbf{x}) = \frac{1}{2}\|A\mathbf{x} - \mathbf{b}\|^2$ بخطوتين (تدرّج ثم فارق).

١٧. أوجد $\nabla_X \ln\det(X)$ عند $X = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}$ وقارن بالحساب المباشر.

١٨. اكتب backprop كاملاً لشبكة: $\hat{y} = w_2 \tanh(w_1 x)$ بخسارة $\frac{1}{2}(\hat{y} - y)^2$ (كل التدرّجات).

١٩. أثبت أنّ softmax هو حلّ مسألة تعظيم الإنتروبيا السلبية على simplex بمتوسط مقيد (لاغرانج — استباقاً).

٢٠. تحدٍّ تركيبي: «لماذا أضافت ϵ إلى LayerNorm؟» — احسب تدرّج $\frac{x}{\sqrt{\sigma^2+\epsilon}}$ عند $\mathbf{x} = 0$، وقارنه بالمشتق بلا ϵ، وربط بالأخطاء العددية للفصل 6 (الإلغاء والحساسية).

- **اليعقوبية (1.9):** $J_{ij} = \partial f_i / \partial x_j$ — خريطة الحساسيات الكاملة؛ التدرّج حالة خاصة.
- **الهِسّية (2.9):** متماثلة (شوارتز)، وقيمها الذاتية تصنّف النقاط الحرجة (حوض/سرج/قمة) وتقيس الـ conditioning.
- **السلسلة (3.9):** $J_{g\circ f} = J_g J_f$ — أمامياً بـ A، عكسياً بـ $A^\top$؛ الضرب المتكرر هو التلاشي/الانفجار.
- **القواعد الأثرية (5.9):** $\nabla \mathrm{tr}(AX) = A^\top$، $\nabla \ln\det = X^{-1}$ — أدوات الحساب السريع.
- **كنوز التطبيق (6.9)–(7.9):** softmax يعقوبيتها $\mathrm{diag}(s) - ss^\top$؛ مع cross-entropy تختزل إلى $\mathbf{s} - \mathbf{y}$؛ والريج إلى $(X^\top X + \lambda I)^{-1} X^\top \mathbf{y}$.

الرمز	المعنى	أين عُرّف
$J_{\mathbf{f}}$	اليعقوبية $m \times n$	(1.9)
$\nabla_{\mathbf{x}} f$	التدرّج (صفّ)	قسم 2.9
$H = \nabla^2 f$	الهِسّية	(2.9)
$H \succeq 0$	شبه موجبة (محدَّبة)	نظرية 2.3.9
$J_{g\circ f} = J_g J_f$	السلسلة	(3.9)
$\mathrm{diag}(\mathbf{s}) - \mathbf{s}\mathbf{s}^\top$	يعقوبية softmax	(6.9)
$\mathbf{s} - \mathbf{y}$	تدرّج cross-entropy	(7.9)

١. H. Neudecker, & J. Magnus, (2019). *Matrix Differential Calculus*, 3rd ed., Wiley — المرجع الكنسي لقواعد الأثر والتفاضل المصفوفي.

٢. K. Petersen, & M. Pedersen, (2012). *The Matrix Cookbook* — جداول جاهزة لمشتقّات المصفوفات (مرجع سريع).

٣. A. Griewank, & A. Walther, (2008). *Evaluating Derivatives*, SIAM — التفاضل الآلي: اليعقوبية والهِسّية بكفاءة.

٤. S. Wright, & J. Nocedal, (2006). *Numerical Optimization*, 2nd ed., Springer (الفصل 2: النظرية غير المقيّدة والهِسّية؛ الفصل 3: الأشكال الثنائية).

٥. I., Goodfellow, Y. Bengio, & A. Courville, (2016). *Deep Learning*, MIT Press (الفصل 6: التفاضل المصفوفي للشبكات).

٦. L. Vandenberghe, & S. Boyd, (2004). *Convex Optimization*, Cambridge (الفصل 3: التقوّس و Hessian؛ الفصل 9: تدرّج القيود).

٧. A. Baydin, et al. (2018). "Automatic Differentiation in Machine Learning: a Survey". *JMLR* 18 — مسح شامل للتفاضل الآلي الأمامي/العكسي.

٨. A. Vaswani, et al. (2017). "Attention Is All You Need". *NeurIPS* — softmax الانتباه الذي بنينا تدرّجه في مثال 6.9-8.

التكامل، نظرية القياس، وتكامل ليبيسغ–ستيلتjes

الهدف من الفصل

رابع فصول الجزء الثاني (التفاضل والتكامل). أنهينا النهايات (7) والمشتقّ القياسي (8) والتفاضل المصفوفي (9). الآن ننتقل من «الاشتقاق» إلى «التكامل» لكن بأساسٍ صارم: نظرية القياس. كلّ «توقّع» (expectation) في التعلم الآلي هو تكامل ليبيسغ–ستيلتjes على فضاء الاحتمال، وكل «مخاطرة متوقّعة» (expected risk) هي $\int L \, d\mathbb{P}$. بلا هذا الفصل لا معنى رياضيّ دقيق لـ divergence KL ولا لـ ELBO ولا لـ SDE. dffiusion

أربعة دوافع تجعل هذا الفصل غير قابل للتجاوز:

١. **الاشتقاق والتكامل ليسا متناظرين:** تكامل ريمان ينهار على دوالّ «قفزات كثيفة» (مثل دالة ديريكليه) التي تظهر طبيعياً في الاحتمالات (متغيّرات عشوائية مختلطة). تكامل ليبيسغ يتعامل معها بسلاسة.

٢. **التوقّع هو تكامل:** $\mathbb{E}[X] = \int X \, d\mathbb{P}$؛ و «تكامل ليبيسغ–ستيلتjes» هو بالضبط ما يربط التوزيع (دالة كثافة التوزيع F) بالتوقّع — أساس كل إحصاء في الذكاء الاصطناعي.

٣. **مبرهنات التقارب** (MCT / Fatou / DCT) هي «الأدوات القانونية» التي تسمح بتبادل الحدّ والتكامل — وهو ما نفعله كلّما حوّلنا مجموع خسائر على عيّنات إلى توقّع على التوزيع.

٤. **التعلّم الإحصائي** (الجزء السادس لاحقاً) يقوم على قياس «المسافة» بين توزيعات — وهي مفاهيم قياسية صرفة.

خريطة الفصل

القسم	الموضوع	الأداة المركزية
1.10	فضاءات القياس وسيغما-جبرا	$(\Omega, \mathcal{F}, \mu)$
2.10	قياس ليبيسغ والقياس الخارجي	الترجمة-ثابت $m(E)$
3.10	الدوال القياسية والدوال البسيطة	$\phi = \sum a_i \mathbf{1}_{A_i}$
4.10	تكامل ليبيسغ	$\int f \, d\mu$
5.10	مبرهنات التقارب	DCT · Fatou · MCT
6.10	تكامل ليبيسغ–ستيلتjes	$\int h \, dF$

التعريف

Definition 1.2.10 (σ-algebra & measure). Let Ω be a set. A collection $\mathcal{F} \subseteq 2^{\Omega}$ is a **σ-algebra** fi (i) $\varnothing \in \mathcal{F}$; (ii) $A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$; (iii) $A_1, A_2, \dots \in \mathcal{F} \Rightarrow \bigcup_n A_n \in \mathcal{F}$.
A **measure** is $\mu : \mathcal{F} \to [0, \infty]$ with $\mu(\varnothing) = 0$ and **countable additivity**:

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n) \quad \text{disjoint for} A_n \in \mathcal{F}. \tag{1.10}$$

dir="ltr"> <div
space. probability a is it $\mu(\Omega) = 1$ If **.space measure** a is $(\Omega, \mathcal{F}, \mu)$ triple The

النظرية 1.2.10 (الاستمرارية). لقياس μ ومتتاليات $A_n \uparrow A$ (تصاعدياً) أو $B_n \downarrow B$ مع $\mu(B_1) < \infty$ (هبوطياً):

$$\mu(A) = \lim_{n\to\infty} \mu(A_n), \qquad \mu(B) = \lim_{n\to\infty} \mu(B_n).$$

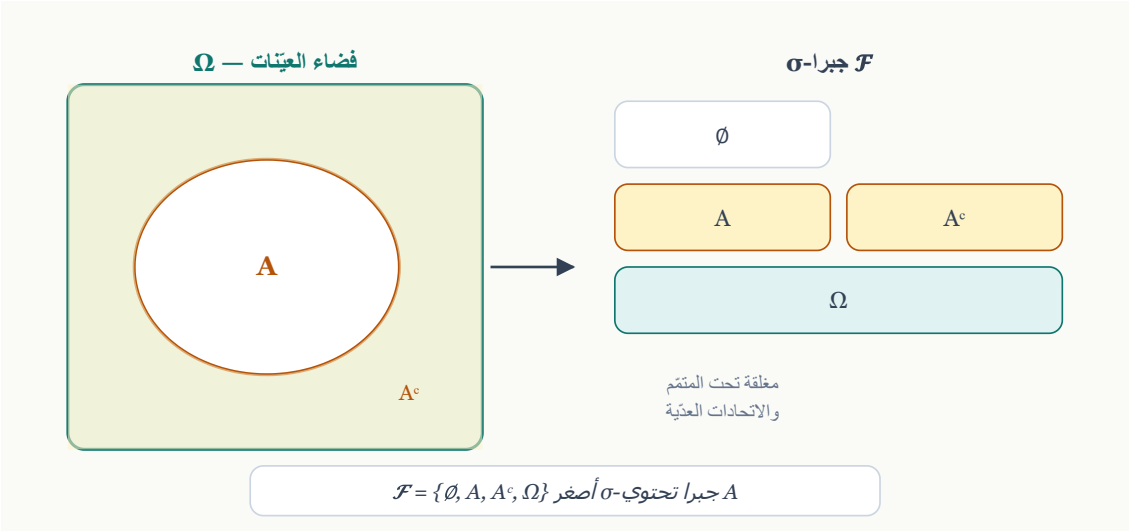
النظرية 2.2.10 (الإنحماد). لـ $A \subset B$: $\mu(A) \le \mu(B)$؛ ولأيّ A, B: $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$.

جدول الرموز

الرمز	الاسم	المعنى
Ω	فضاء العيّنات	المجموعة الكلية للنتائج
$\mathcal{F}$	سيغما-جبرا	عائلة المجموعات «القياسية»
μ	القياس	دالة حجم غير سالبة قابلة للجمع عدّياً
$\sigma(\mathcal{C})$	σ-جبرا المولّدة	أصغر σ-جبرا تحوي $\mathcal{C}$

رسم توضيحي

<figure> الشكل<figcaption> 1.10: σ-جبرا $\mathcal{F}$ ليست «كل المجموعات الفرعية» بل أصغر عائلة مغلقة تحت المتمّم



شكل ١٠.١٠: *
سيغما-جبرا كأصغر عائلة مغلقة تحت المتمّم والاتحاد

والاتحادات العدّية. لنقطة/مجموعة A نحصل على العائلة الرباعية $\{\emptyset, A, A^c, \Omega\}$.</figcaption></figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«الاتحاد المنتهي يكفي»	σ-جبرا تتطلّب اتحادات عدّية لا منتهية فقط	الاتحاد المنتهي ناتج عن شرطي (ii),(iii)
نسيان أنّ $\mu(\emptyset)=0$ إلزامي	بلاها ينهار الجمع العدّي	ابدأ كل برهان بها
اعتبار 2^Ω دائماً هي σ-جبرا المناسبة	أحياناً «كبيرة أكثر from اللازم» (غير قياسية)	استخدم $\sigma(\mathcal{C})$ الأصغر المناسبة
الخلط بين «مجموعة قياسية» و«لها قياس منتهٍ»	القياس قد يصل ∞	شرط مستقلّ $\mu(A)<\infty$

أمثلة محلولة على فضاءات القياس وسيغما-جبرا (15 مثالاً)

مثال (10،2-1).

- **المعطيات:** $\Omega=\{1,2,3\}$، $\mathcal{F}=2^\Omega$.
- **المطلوب:** تحقّق أنّ $\mathcal{F}$ σ-جبرا وحدّد قياساً عليها.
- **الحل:**

١. $\emptyset\in\mathcal{F}$ واضح؛ المتمّمات والاتحادات تبقى ضمن الـ 8 مجموعات.

٢. عرّف $\mu(A)=|A|$ (قياس العدّ).

٣. $\mu(\emptyset)=0$، ولمنفصلة A,B: $\mu(A\cup B)=|A|+|B|$. ■

- **النتيجة:** 2^Ω أكبر σ-جبرا دائماً، μ قياس عدّ.

- **الربط بالذكاء الاصطناعي:** قياس العدّ على فضاء منتهٍ = «توزيع احتمال منفصل»؛ كل شبكة تصنيف تُعلّم احتمالات $\mu(\{\text{صنف}\})$.

مثال (10،2-2).

- **المعطيات:** $\Omega=\{a,b,c\}$، $A=\{a\}$.
- **المطلوب:** أصغر σ-جبرا تحتوي A.
- **الحل:**

١. نبدأ بـ $\emptyset,\Omega$ و A.

٢. المتمّم $A^c=\{b,c\}$ يجب أن يكون موجوداً.

٣. لا اتحادات جديدة (الأربعة مغلقة). ■

- **النتيجة:** $\mathcal{F}=\{\emptyset,\{a\},\{b,c\},\Omega\}$.

- **الربط بالذكاء الاصطناعي:** «تقسيم الفضاء إلى خلايا» — أصغر σ-جبرا = أضعف قدرة على التمييز؛ أساس ميزات التجميع (clustering) الخشنة.

مثال (2.10-3).

- **المعطيات:** $\Omega = \mathbb{R}$، $\mathcal{C}$ = كل الفترات المفتوحة (a, b).
- **المطلوب:** ما $\sigma(\mathcal{C})$؟
- **الحل:**

١. الفترات المفتوحة تولّد **سيغما-جبرا بوريل** $\mathcal{B}(\mathbb{R})$.

٢. كل فترة مغلقة/نصف مفتوحة/نقطة منتمية لها (مثلاً $\{x\} = \bigcap_n (x - 1/n, x + 1/n)$). ■

- **النتيجة:** $\mathcal{B}(\mathbb{R})$ تحتوي كل المجموعات «العملية» (فترات، نقاط، أقراص مفتوحة).

- **الربط بالذكاء الاصطناعي:** كل دوالّ الاحتمال المستمرّة «بوريل-قياسية» — هذا يجعل احتمال أيّ حدث $(X \le x)$ معرّفاً.

مثال (2.10-4).

- **المعطيات:** $A_1, A_2, \ldots$ منفصلة، $\mu(A_n) = 2^{-n}$.
- **المطلوب:** $\mu\left(\bigcup_n A_n\right)$.
- **الحل:**

١. بالجمع العدّي (1.10): $\sum_{n=1}^{\infty} 2^{-n} = 1$. ■

- **النتيجة:** 1.

- **الربط بالذكاء الاصطناعي:** «هندسة الاحتمالات اللانهائية» — مجموع كثافات نقاط = 1، تماماً كتوزيع احتمالي على عدد لا نهائي من الأصناف (مثل نموذج لغوي).

مثال (2.10-5).

- **المعطيات:** $A_n \uparrow A$، $\mu(A_n) = 1 - 1/n$ على فضاء بـ $\mu(A) = 1$.
- **المطلوب:** تحقّق الاستمرارية من الأسفل.
- **الحل:**

١. $A_n \subset A_{n+1}$ و $\bigcup A_n = A$.

٢. النظرية 1.2.10: $\lim \mu(A_n) = \lim(1 - 1/n) = 1 = \mu(A)$. ■

- **النتيجة:** $\mu(A_n) \to \mu(A)$ (= الاستمرارية من الأسفل).

- **الربط بالذكاء الاصطناعي:** تقارب سلسلة تدريب تدريجياً نحو «الحل الكامل» — قياس «المجموعة المكتشفة» يزداد إلى القيمة النهائية.

مثال (2.10-6).

- **المعطيات:** $B_n \downarrow \{0\}$، $B_n = [-1/n, 1/n]$، $\mu =$ ليبيسغ.
- **المطلوب:** $\lim \mu(B_n)$ مع التحقّق من شرط الانهماك المحدود.
- **الحل:**

١. $\mu(B_1) = 2 < \infty$ (منهدم محدود).

٢. $\mu(B_n) = 2/n \to 0 = \mu(\{0\})$. ■

- **النتيجة:** 0 — نقطة لها قياس صفر.
- **الربط بالذكاء الاصطناعي:** «النقطة الواحدة بلا وزن» في التوزيعات المستمرّة — سبب أنّ $P(X = x) = 0$ دائماً للمتغيّر المستمرّ.

مثال (2.10-7).

- **المعطيات:** μ قياس، $A \subset B$، $\mu(B) = 5$.
- **المطلوب:** حدود $\mu(A)$ والأعمدة.
- **الحل:**

١. بالإنحماد: $0 \le \mu(A) \le 5$.

٢. $\mu(B \setminus A) = \mu(B) - \mu(A) = 5 - \mu(A)$ (لأنّ B منتهية). ■

- **النتيجة:** $\mu(A) \in [0, 5]$.
- **الربط بالذكاء الاصطناعي:** «الخطأ على مجموعة فرعية $\le$ الخطأ الكلّي» — أساس كل تقدير خطأ علوي (upper bound) في التعلّم.

مثال (2.10-8).

- **المعطيات:** $\mu(A) = 3,\ \mu(B) = 4,\ \mu(A \cap B) = 1$.
- **المطلوب:** $\mu(A \cup B)$.
- **الحل:**

١. النظرية 2.2.10: $3 + 4 - 1 = 6$. ■

- **النتيجة:** 6.
- **الربط بالذكاء الاصطناعي:** مبدأ الشمول والاستبعاد (قانون 2.1) هو حالة منتهية من قابلية الجمع — نفس الرياضيات تربط الفصلين 1 و10.

مثال (2.10-9).

- **المعطيات:** $\Omega = \mathbb{R}$، $\mu =$ قياس ليبيسغ، $A = \{7\}$.
- **المطلوب:** $\mu(A)$.
- **الحل:**

١. نقطة = تقاطع فترات $[7, 7 + 1/n]$؛ قياسها $\leq 1/n$ لكل n.

٢. إذن $\mu(\{7\}) = 0$. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** مستمرّ $\neq$ منفصل؛ النقاط بلا كتلة — لذلك نحتاج كثافة $p(x)$ لا احتمال نقطي.

مثال (2.10-10).

- **المعطيات:** $\mu(\Omega) = 1$، الأحداث A, B بـ $\mu(A) = 0.6, \mu(B) = 0.4, \mu(A \cap B) = 0.2$.
- **المطلوب:** هل μ احتمال؟ وما $\mu(A \cup B)$؟
- **الحل:**

١. $\mu(\Omega) = 1$ والمتطلّبات محقّقة $\Longrightarrow$ مساحة احتمال.

٢. $\mu(A \cup B) = 0.6 + 0.4 - 0.2 = 0.8$. ■

- **النتيجة:** احتمال، الاتحاد 0.8.
- **الربط بالذكاء الاصطناعي:** جدول احتمالات مشترك (join) (probability — أساس بايز والشبكات الاحتمالية.

مثال (2.10-11).

- **المعطيات:** X, Y فضاءان، $\mathcal{F}_X, \mathcal{F}_Y$ σ-جبرات.
- **المطلوب:** عرّف σ-جبرا الجداء على $X \times Y$.
- **الحل:**

١. $\mathcal{F}_X \otimes \mathcal{F}_Y = \sigma(\{A \times B : A \in \mathcal{F}_X, B \in \mathcal{F}_Y\})$.

٢. تولّد من «مستطيلات قياسية». ■

- **النتيجة:** σ-جبرا الجداء.
- **الربط بالذكاء الاصطناعي:** فضاء الميزات المشترك (صورة × نص) — أحداثه منتجات أحداث أصلية؛ أساس نماذج الاحتمال المشترك.

مثال (12-2.10).

- **المعطيات:** $\Omega = \{1, 2\}$، $\mathcal{F} = \{\emptyset, \Omega\}$ (σ-جبرا تافهة).
- **المطلوب:** هل يمكن لدالة $f : \Omega \to \mathbb{R}$ أن تكون غير ثابتة وقابلة للقياس؟
- **الحل:**

١. $\{\omega : f(\omega) > a\}$ يجب أن تكون $\emptyset$ أو Ω لكل a.

٢. هذا يفرض $f(1) = f(2)$ دائماً. ■

- **النتيجة:** كل دالة قياسية هنا ثابتة.

- **الربط بالذكاء الاصطناعي:** «أضعف σ-جبرا = أقلّ معلومات» — مشابه لما لا تستطيع طبقة بلا ميزات تمييزه؛ ربط بالتعلّم غير القابل للتعلّم VC) بعداً).

مثال (13-2.10).

- **المعطيات:** $\mathcal{A} = \{\emptyset, \{1\}\}$، $\mathcal{B} = \{\emptyset, \{2\}\}$ على $\Omega = \{1, 2, 3\}$.
- **المطلوب:** هل اتحاد $\mathcal{A} \cup \mathcal{B}$ σ-جبرا؟
- **الحل:**

١. $\{1, 2\} = \{1\} \cup \{2\}$ يجب أن يكون عضواً لكنه ليس في الاتحاد.

٢. إذن الاتحاد ليس σ-جبرا. ■

- **النتيجة:** لا.

- **الربط بالذكاء الاصطناعي:** «دمج ميزاتين» لا يكفي أحياناً — يجب أخذ الـ σ-جبرا المولّدة (كل التفاعلات)، تماماً كدمج مميّزات في شبكة.

مثال (14-2.10).

- **المعطيات:** $\mathcal{C} = \{(-\infty, a] : a \in \mathbb{R}\}$.
- **المطلوب:** أثبت أنّ $\sigma(\mathcal{C}) = \mathcal{B}(\mathbb{R})$.
- **الحل:**

١. كل $(-\infty, a]$ بوريل $\Longrightarrow \sigma(\mathcal{C}) \subset \mathcal{B}$.

٢. العكس: $(a, b] = (-\infty, b] \setminus (-\infty, a]$ بوريل، والفترات نصف المفتوحة تولّد $\mathcal{B}$. ■

- **النتيجة:** تتساوى.

- **الربط بالذكاء الاصطناعي:** $F(x) = P(X \leq x)$ تُعرّف على $(-\infty, a]$ — لهذا التوزيعات تُحدَّد بـ CDF يسار-مستمر لا بالكثافة.

مثال (15-2.10).

- **المعطيات:** فضاء منتهٍ $\Omega = \{x_1, \dots, x_n\}$، أوزان $w_i \geq 0$، $\sum w_i = 1$.
- **المطلوب:** عرّف قياس احتمال منه.
- **الحل:**

١. لكل A: $\mu(A) = \sum_{x_i \in A} w_i$.

٢. $\mu(\Omega) = 1$ والمتطلّبات محقّقة. ■

- **النتيجة:** توزيع احتمالي منفصل عامّ.
- **الربط بالذكاء الاصطناعي:** softmax يُنتج بالضبط هذه الأوزان w_i — «توزيع فئوي» جاهز للتوقّع.

التعريف

dir="ltr"> <div
Definition 1.3.10 (Lebesgue outer measure). For $E \subset \mathbb{R}^d$:

$$m^*(E) = \inf\Big\{ \sum_{k=1}^{\infty} \ell(I_k) : E \subset \bigcup_{k} I_k \Big\},$$

where I_k are d-dimensional intervals, ℓ their volume. E is **Lebesgue measurable** if for every test set A:

$$m^*(A) = m^*(A \cap E) + m^*(A \cap E^c).$$

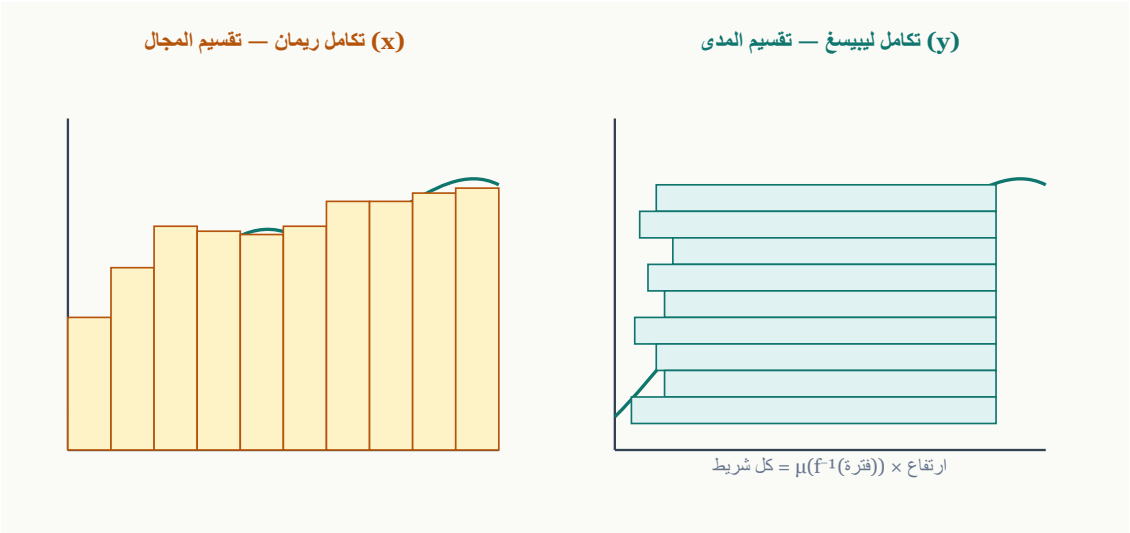
$$m([a,b]) = b - a, \qquad m(\mathbb{Q} \cap [0,1]) = 0. \tag{2.10}$$

النظرية 1.3.10 (خصائص قياس ليبيسغ m):

- **ثبات الترجمة:** $m(E + x) = m(E)$.
- **التجانس:** $m(cE) = |c|^d m(E)$.
- **العدديّة:** للمجموعات المنفصلة $\bigcup E_n$، $m = \sum m(E_n)$.
- **العدّيّة الخارجية:** $m^*(\bigcup E_n) \leq \sum m^*(E_n)$ (لا تطلب منفصلة).

جدول الرموز

الرمز	الاسم	المعنى
$m^*(E)$	القياس الخارجي	أصغر غطاء بمكعّبات
$m(E)$	قياس ليبيسغ	الطول/المساحة/الحجم المعتاد
$\ell(I)$	حجم الفترة	طول/حجم المنطقة I



شكل ٢٠١٠: *
ريمان يقسّم المجال، ليبيسغ يقسّم المدى

رسم توضيحي

<figure> الشكل<figcaption> 2.10: ريمان يقسّم محور x (أشرطة رأسية)؛ ليبيسغ يقسّم محور y (أشرطة أفقية بحسب «مقدار ما قبل الصورة»). هذه الرؤية تسمح بدمج «القفزات» التي تفشل عند ريمان.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«كل مجموعة قابلة للقياس»	توجد مجموعات غير قياسية (فيتالي)	معظم المجموعات العملية قياسية
$m^*(\cup E_n) = \sum m^*(E_n)$ دائماً	العدّية الخارجية متراجحة فقط	تحتاج منفصلة للتساوي
«لأنّ $\mathbb{Q}$ كثيفة» $m(\mathbb{Q}) = 1$	الكثافة لا تعني القياس	$\mathbb{Q}$ عدّية $\Rightarrow$ قياسها 0
الخلط $m([a,b])$ مع $m((a,b))$	كلاهما $b-a$	النقاط بلا قياس

أمثلة محلولة على قياس ليبيسغ (15 مثالاً)

مثال (10.3-1).

- **المعطيات:** $E = [2, 5]$.
- **المطلوب:** $m(E)$.
- **الحل:**

١. من (2.10): الطول $= 5 - 2 = 3$. ■

- **النتيجة:** 3.
- **الربط بالذكاء الاصطناعي:** «عرض نافذة زمنية» في تسلسل بيانات = قياسها؛ أساس تجميع النوافذ.

مثال (3.10-2).

- **المعطيات:** $E = (0,1) \cap \mathbb{Q}$.
- **المطلوب:** $m(E)$.
- **الحل:**

١. $\mathbb{Q}$ عدّية، كل نقطة قياسها 0.

٢. اتحاد عدّي لنقاط $\Rightarrow$ القياس 0. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** مجموعة «كثيفة لكن بلا حجم» — تذكير بأنّ الاحتمال النقطي للمستمرّ صفر رغم كثافة النقاط.

مثال (3.10-3).

- **المعطيات:** مجموعة كانتور C على $[0,1]$.
- **المطلوب:** $m(C)$.
- **الحل:**

١. تُبنى بحذف أثلاث: في الخطوة n نحذف 2^{n-1} فترة طول 3^{-n}.

٢. المحذوف كلّياً: $\sum_{n=1}^{\infty} 2^{n-1}3^{-n} = \frac{1}{3}/(1-\frac{2}{3}) = 1$.

٣. إذن $m(C) = 1 - 1 = 0$ (مع أنّها غير عدّية!). ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «مجموعة لا حجم لها لكن لا تُعدّ» — تحذير رياضي: القياس الصفري لا يلغي الأهمية (مثل مجموعة المعاملات النادرة).

مثال (3.10-4).

- **المعطيات:** $E = [0,1]$، انقلها: $E + 3 = [3,4]$.
- **المطلوب:** $m(E+3)$ (ثبات الترجمة).
- **الحل:**

١. $m(E+3) = m(E) = 1$. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** «إزاحة البيانات» (data shfit) لا تغيّر قياس التوزيع — أساس فرضية i.i.d. تحت الترجمة.

مثال (10.3-5).

- **المعطيات:** $E = (0,1)$، $2E = (0,2)$.
- **المطلوب:** $m(2E)$ (التجانس).
- **الحل:**

١. $m(2E) = |2|^1 \, m(E) = 2$. ■

- **النتيجة:** 2.

- **الربط بالذكاء الاصطناعي:** تغيير مقياس الميزة (scaling) يضرب القياس — سبب تطبيع (normalization) البيانات قبل التدريب.

مثال (10.3-6).

- **المعطيات:** $E_1 = (0,1)$، $E_2 = (1,2)$ (منفصلتان).
- **المطلوب:** $m(E_1 \cup E_2)$.
- **الحل:**

١. منفصلتان $\Longrightarrow$ الجمع العدّي: $1 + 1 = 2$. ■

- **النتيجة:** 2.

- **الربط بالذكاء الاصطناعي:** «اندماج فئتين منفصلتين» لا تداخل $\Longrightarrow$ المساحة مجموع — قاعدة في تقدير كثافة الخليط.

مثال (10.3-7).

- **المعطيات:** $E_n = (0, 1/n)$، $n = 1, 2, \ldots$
- **المطلوب:** $m^*(\bigcup_n E_n)$ بـ العدّيّة الخارجية.
- **الحل:**

١. $\bigcup_n E_n = (0,1)$.

٢. $m^*(\cup E_n) = 1 \leq \sum 1/n = \infty$ (المتراجحة صحيحة). ■

- **النتيجة:** 1 (والمتراجحة تحقّق).

- **الربط بالذكاء الاصطناعي:** «غطاء فضفاض» يعطي حدّاً أعلى — مبدأ الـ bounds covering في تحليل العيّنات.

مثال (10.3-8).

- **المعطيات:** مجموعة كانتور «سمينة» (fat Cantor) بقياس نهائي $1/2$.
- **المطلوب:** بيّن إمكانية $m(C) > 0$ مع عدم فترة.
- **الحل:**

١. احذف أطوالاً مجموعها $1/2$ بدل 1.

٢. الباقي قياسه $1/2 > 0$ ومع ذلك لا يحوي أيّ فترة مفتوحة. ■

- **النتيجة:** قياس موجب بلا فترات.
- **الربط بالذكاء الاصطناعي:** «توزيع بلا كثافة ناعمة لكن بكتلة» — نظير التوزيعات المختلطة (mixed discrete-continuous) في الاحتمال.

مثال (10.3-9).

- **المعطيات:** $E = \mathbb{R} \setminus \mathbb{Q}$ (الأعداد غير النسبية في $[0,1]$).
- **المطلوب:** $m(E \cap [0,1])$.
- **الحل:**

١. $[0,1] = (E \cap [0,1]) \cup (\mathbb{Q} \cap [0,1])$.

٢. القسم العقلاني قياسه $0 \Rightarrow$ الآخر قياسه 1. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** «تقريباً كل نقطة غير نسبية» — لهذا تجاهل القيم النسبية في التكاملات المستمرّة بلا أثر.

مثال (10.3-10).

- **المعطيات:** U مفتوحة في $\mathbb{R}$ = اتحاد فترات مفتوحة (a_k, b_k) منفصلة.
- **المطلوب:** $m(U)$.
- **الحل:**

١. $m(U) = \sum (b_k - a_k)$. ■

- **النتيجة:** مجموع الأطوال.
- **الربط بالذكاء الاصطناعي:** «حجم منطقة الثقة» = مجموع أطوال فترات — خرائط الثقة (confidence regions) في الانحدار.

مثال (11-3.10).

- **المعطيات:** F مغلقة = $\mathbb{R} \setminus U$، U مفتوحة كما بالسابق.
- **المطلوب:** $m(F \cap [0,1])$.
- **الحل:**

١. $1 - m(U) = 1 - \sum(b_k - a_k)$. ■

- **النتيجة:** المتمّم القياسي.
- **الربط بالذكاء الاصطناعي:** «المنطقة الخارجة عن الثقة» تقاس بالمتمّم — خطأ النوع الثاني تحليلياً.

مثال (12-3.10).

- **المعطيات:** $A_n = [0, 1 + 1/n]$.
- **المطلوب:** $m(\bigcap_n A_n)$.
- **الحل:**

١. التقاطع $= [0,1]$.

٢. القياس $= 1$. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** «تقاطع شروط متزايدة الصرامة» يضيّق الحدث إلى النواة — مشابه لـ intersection-over-union في الكشف.

مثال (13-3.10).

- **المعطيات:** E عدّية في $\mathbb{R}^d$ لأيّ d.
- **المطلوب:** $m(E)$.
- **الحل:**

١. كل نقطة قياسها 0؛ اتحاد عدّي $\Longrightarrow$ 0. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** مجموعة المعالم النادرة outliers) منفصلون) بلا «حجم» قياسي — سبب صعوبة تقدير كثافتهم.

مثال (14-3.10).

- **المعطيات:** $m([a,b]) = b-a$ و $[a,b]$ مقابل (a,b) مقابل $(a,b]$.
- **المطلوب:** قارن قياساتها.
- **الحل:**

١. النهايات نقاط قياسها 0، كلها $b-a$. ■

- **النتيجة:** متساوية.
- **الربط بالذكاء الاصطناعي:** «حدود الفترة بلا أثر على التكامل» — لذلك نكتب $\int_a^b$ بلا اهتمام بالنهايات.

مثال (15-3.10).

- **المعطيات:** $m^*(E_1 \cup E_2) \le m^*(E_1) + m^*(E_2)$ مع E_1 قابلة للقياس.
- **المطلوب:** أثبت التراجع باستخدام قابلية القياس.
- **الحل:**

١. $m^*(E_1 \cup E_2) = m^*((E_1 \cup E_2) \cap E_1) + m^*(\cdots \cap E_1^c) = m^*(E_1) + m^*(E_2 \cap E_1^c) \le m^*(E_1) + m^*(E_2)$. ■

- **النتيجة:** متراجحة العدّيّة الخارجية.
- **الربط بالذكاء الاصطناعي:** «الخطأ الكلّي ≤ مجموع الأخطاء» — أساس تحليل تعميم التعلّم الإحصائي (union bound لاحقاً).

التعريف

dir="ltr"> <div
for ffi **measurable** is $f : (X, \mathcal{F}) \to (\mathbb{R}, \mathcal{B})$ **function).** **(Measurable 1.4.10 Definition**
,B set Borel every

$$f^{-1}(B) \in \mathcal{F}.$$

.$a \in \mathbb{R}$ all for $\{x : f(x) > a\} \in \mathcal{F}$ Equivalently
form the has **function simple** A

$$\phi(x) = \sum_{i=1}^{k} a_i \, \mathbf{1}_{A_i}(x), \qquad A_i \in \mathcal{F}. \tag{3.10}$$

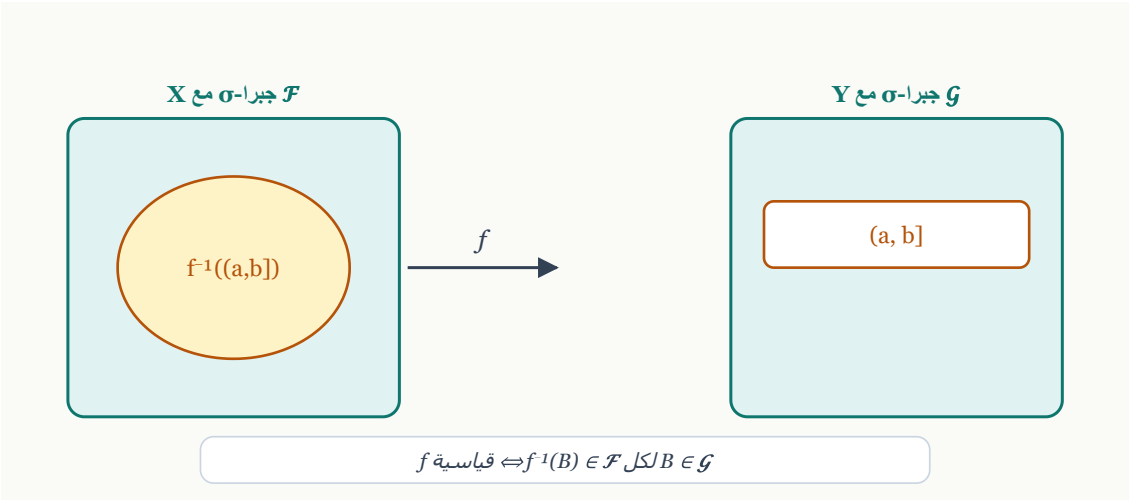
النظرية 1.4.10 (التقريب). كل دالة قياسية غير سالبة = حدّ تصاعدي لدوالّ بسيطة: $0 \le \phi_n \uparrow f$. وكل دالة قياسية عامّة تفاضل إلى $f^+ - f^-$.

جدول الرموز

الرمز	الاسم	المعنى
$f^{-1}(B)$	الصورة العكسية	$\{x : f(x) \in B\}$
$\mathbf{1}_A$	دالة المؤشّر	1 على A و0 خارجها
ϕ	دالة بسيطة	عدد منتهٍ من الخطوات

رسم توضيحي

<figure> الشكل<figcaption>3.10: f قياسية $\iff$ صورة أيّ فترة $(a, b]$ عكسياً تقع في $\mathcal{F}$. الرسم يُظهر $(a, b]$



شكل ٣.١٠: *
الدالة القياسية: صورة كل بوريل عكسياً قياسية

في المستقرّ، وصورتها العكسية (المظلّلة) في الفضاء المصدري يجب أن تكون قياسية.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«القياس على المجال يكفي»	يجب فحص الصورة العكسية	تحقّق $f^{-1}(B) \in \mathcal{F}$
الخلط بين قياس f وقياس المجموعة	f قياسية $\neq \int f$ منتهٍ	القياس شرط، التكامل قيمة
نسيان أنّ الحدّ لدوالّ قياسية قياسي	الحدّ يحافظ القياسيّ	مبرهنة مهمّة للتقارب
اعتبار الدالة البسيطة «تافهة»	كل f تُقرَّب بها	أساس بناء التكامل

أمثلة محلولة على الدوال القياسية (15 مثالاً)

مثال (10.4-1).

- **المعطيات:** $f = \mathbf{1}_A$، $A \in \mathcal{F}$.
- **المطلوب:** هل f قياسية؟
- **الحل:**

١. لـ $t < 0$: $f^{-1}((t, \infty)) = \emptyset$.

٢. لـ $0 \leq t < 1$: A؛ لـ $t \geq 1$: X. كلها في $\mathcal{F}$. ■

- **النتيجة:** نعم — المؤشّر قياسي دائماً لـ A قياسية.
- **الربط بالذكاء الاصطناعي:** «دالة التنشيط الخطوة» في العتبة (threshold) — قياسية، لذا احتمالها معرّف.

مثال (10.4-2).

- **المعطيات:** $f(x) = x$ على $\mathbb{R}$ بوريل.
- **المطلوب:** القياس.
- **الحل:**

١. $\{x : x > a\} = (a, \infty)$ بوريل. ■

- **النتيجة:** قياسية.
- **الربط بالذكاء الاصطناعي:** الميزة المستمرّة قياسية — كل ميزة خام تصلح كـ input للتوقّع.

مثال (10.4-3).

- **المعطيات:** g مستمرّة، f قياسية.
- **المطلوب:** هل $g \circ f$ قياسية؟
- **الحل:**

١. g مستمرّة $\Longrightarrow$ معكوس الفترة مفتوحة؛ $(g \circ f)^{-1}((a, \infty)) = f^{-1}(g^{-1}((a, \infty)))$.

٢. الداخل بوريل $\Longrightarrow$ الخارج قياسي بقياس f. ■

- **النتيجة:** نعم.
- **الربط بالذكاء الاصطناعي:** تطبيق تنشيط مستمرّ (ReLU, sigmoid) على طبقة قياسية يبقيها قياسية — كل مخرجات الشبكة «قياسية».

مثال (10.4-4).

- **المعطيات:** f, g قياسيتان.
- **المطلوب:** هل $\max(f, g)$ قياسية؟
- **الحل:**

١. $\{\max(f, g) > a\} = \{f > a\} \cup \{g > a\} \in \mathcal{F}$. ■

- **النتيجة:** نعم.
- **الربط بالذكاء الاصطناعي:** max-pooling قياسي — عمليات الطبقات التلافيفية تحافظ القياس.

مثال (10.4-5).

- **المعطيات:** $f_n \to f$ نقطةً بنقطة، كل f_n قياسية.
- **المطلوب:** هل f قياسية؟
- **الحل:**

١. $\{f > a\} = \bigcup_{m=1}^{\infty} \bigcup_{N=1}^{\infty} \bigcap_{n \geq N} \{f_n > a + 1/m\}$ قياسي.

٢. اتحادات وتقاطعات عدّية تحفظ $\mathcal{F}$. ■

- **النتيجة:** نعم — الحدّ القياسي قياسي.
- **الربط بالذكاء الاصطناعي:** تقارب شبكة أثناء التدريب يحفظ «قياسية» المخرجات — لا تنشأ قيم غير معرّفة.

مثال (10.4-6).

- **المعطيات:** f قياسية.
- **المطلوب:** هل $|f|$ و f^2 قياسيتان؟
- **الحل:**

١. $|f| > a$ ترجع لفترات على f؛ $f^2 > a$ (=$|f| > \sqrt{a}$) أيضاً. ■

- **النتيجة:** كلاهما قياسي.
- **الربط بالذكاء الاصطناعي:** خسارة MSE تعتمد على f^2 — قياسيتها تضمن أنّ $\mathbb{E}[L]$ معرّف.

مثال (10.4-7).

- **المعطيات:** $\phi(x) = \sum_{i=1}^{3} a_i \mathbf{1}_{A_i}(x)$، A_i منفصلة.
- **المطلوب:** تحقّق أنّها دالة بسيطة.
- **الحل:**

١. مركّبة من 3 مؤشّرات لمنفصلات $\Longrightarrow$ بسيطة بتعريف (10.3). ■

- **النتيجة:** بسيطة.
- **الربط بالذكاء الاصطناعي:** «هيستوغرام» = دالة بسيطة — تقريب أيّ توزيع بعدد منتهٍ من الصناديق.

مثال (4.10-8).

- **المعطيات:** $f(x) = x$ على $[0,1]$، قرّبها بسيطة $\phi_n = \sum_{k=1}^{n} \frac{k-1}{n} \mathbf{1}_{[(k-1)/n,\,k/n)}$.
- **المطلوب:** أثبت $\phi_n \uparrow f$.
- **الحل:**

١. على كل صندوق الخطأ $< 1/n$؛ $\phi_n \le f$ وتتقارب إليها. ■

- **النتيجة:** تقارب من الأسفل.
- **الربط بالذكاء الاصطناعي:** «تكميم الميزة» (quantization) — تقريب المتصل بخطوات، أساس ضغط النماذج.

مثال (4.10-9).

- **المعطيات:** $\mathcal{F} = \{\emptyset, \Omega\}$ تافهة.
- **المطلوب:** ما الدوالّ القياسية؟
- **الحل:**

١. $\{f > a\}$ إمّا $\emptyset$ أو $\Omega \Rightarrow f$ ثابتة. ■

- **النتيجة:** الثوابت فقط.
- **الربط بالذكاء الاصطناعي:** بلا ميزات (σ-جبرا تافهة) لا تعلّم ممكن — نفس استنتاج 12-2.10.

مثال (4.10-10).

- **المعطيات:** $f = \lfloor x \rfloor$ على $\mathbb{R}$.
- **المطلوب:** القياس.
- **الحل:**

١. $\{f > a\} = \bigcup_{k > \lfloor a \rfloor} [k, k+1)$ قياسي. ■

- **النتيجة:** قياسية.
- **الربط بالذكاء الاصطناعي:** التكميم التنازلي (floor) في الترميز الرقمي قياسي — لا يفسد حساب التوقّع.

مثال (4.10-11).

- **المعطيات:** f قياسية، B بوريل.

- **المطلوب:** عرّف توزيع الصورة $\mu_f(B) = \mu(f^{-1}(B))$.
- **الحل:**

١. $f^{-1}(B) \in \mathcal{F} \implies \mu_f$ قياس معرّف جيّداً. ■

- **النتيجة:** قياس الصورة.
- **الربط بالذكاء الاصطناعي:** «توزيع المخرجات» P_Y يحسبها بالضبط — أساس كل توزيع متغيّر عشوائي.

مثال (10.4-12).

- **المعطيات:** $f(x) = e^x$، $g(y) = \ln y$.
- **المطلوب:** هل $g(f(x))$ قياسية؟
- **الحل:**

١. التركيب $x =$ (هوية) قياسية؛ أو عبر مثال 10.4-3. ■

- **النتيجة:** نعم.
- **الربط بالذكاء الاصطناعي:** log-then-exp أو exp-then-log (كـ softmax في log-space) تحافظ القياس — خدعة استقرار عددي من الفصل 6.

مثال (10.4-13).

- **المعطيات:** f قياسية غير سالبة، $\phi_n = \frac{\lfloor 2^n f \rfloor}{2^n} \wedge n$.
- **المطلوب:** بيّن تقريبها من الأسفل.
- **الحل:**

١. كل ϕ_n بسيطة (عدد منتهٍ من القيم)؛ $\phi_n \le f$ وتتقارب. ■

- **النتيجة:** تقارب بسيط من الأسفل.
- **الربط بالذكاء الاصطناعي:** «تقريب التدرّج السفلي» يذكّر بخطوات التعلّم: نقاط منفصلة تتقارب نحو القيمة السلسة.

مثال (10.4-14).

- **المعطيات:** f, g قياسيتان.
- **المطلوب:** هل $f+g$ و fg قياسيتان؟
- **الحل:**

١. $\{f + g > a\}$ يُعبَّر باتحاد عدّي $\{f > q\} \cap \{g > a - q\}$ (عقلات q).

٢. fg عبر $f^2, g^2, (f+g)^2$. ■

- **النتيجة:** نعم لكلّ العمليات الجبرية.

- **الربط بالذكاء الاصطناعي:** أيّ تعبير حسابي على مخرجات الشبكة يبقى قياسياً — لا يخرج عن فضاء الاحتمال.

مثال (4.10-15).

- **المعطيات:** $f = \mathbf{1}_{\mathbb{Q}}$ (ديريكليه).

- **المطلوب:** هل قياسية على $(\mathbb{R}, \mathcal{B})$؟

- **الحل:**

١. $\{f > 1/2\} = \mathbb{Q} \in \mathcal{B}$ (عدّية $\Longrightarrow$ بوريل).

٢. إذن قياسية (رغم كونها «مضطربة»). ■

- **النتيجة:** قياسية.

- **الربط بالذكاء الاصطناعي:** «دالة مضطربة لكن قياسية» — التكامل اللاحق سيعطيها قيمة منطقية (صفر تقريباً) رغم شكلها.

التعريف

dir="ltr"> <div
Definition 1.5.10 (Lebesgue integral). For a simple $\phi = \sum a_i \mathbf{1}_{A_i} \geq 0$:

$$\int \phi \, d\mu = \sum_{i} a_i \, \mu(A_i).$$

For $f \geq 0$: $\int f \, d\mu = \sup \left\{ \int \phi \, d\mu : \ 0 \leq \phi \leq f, \ \phi \text{simple} \right\}$. For general $f = f^+ - f^-$ with $\int |f| d\mu < \infty$: $\int f = \int f^+ - \int f^-$.

$$\int_X (af + bg) \, d\mu = a \int_X f \, d\mu + b \int_X g \, d\mu. \tag{4.10}$$

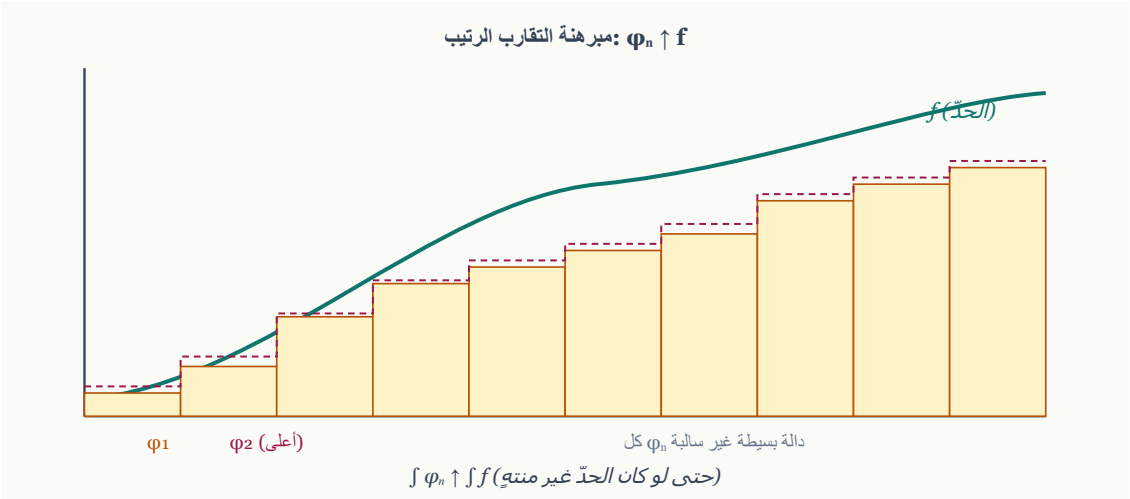
النظرية 1.5.10 (التكافؤ عدّ النقاط). لـ $f \geq 0$ قياسية و $\{x : f(x) > 0\}$ عدّية، $\int f \, d\mu = \sum_x f(x)\mu(\{x\})$.

جدول الرموز

الرمز	الاسم	المعنى
$\int f \, d\mu$	تكامل ليبيسغ	«متوسّط مرجّح بـ μ»
f^+, f^-	الأجزاء الموجبة/السالبة	$\max(f, 0), \max(-f, 0)$
$\int \lvert f \rvert d\mu < \infty$	قابلية التكامل	شرط الاندماج

رسم توضيحي

<figure> الشكل<figcaption> 4.10: نبني $\int f$ كـ sup على الدوالّ البسيطة $\phi_n \uparrow f$. الأشرطة (أسفل) ترتفع نحو



شكل ٤.٠١٠: *
التكامل كحدّ لأعلى دوالّ بسيطة

منحنى f (أعلى)؛ مساحتها تتقارب من الأسفل.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الخلط بين $\int f\,d\mu$ و $\int f(x)dx$	$d\mu$ قياس عامّ	اكتب القياس صراحة
«التكامل يوجد دائماً»	قد يكون ∞	افحص $\int \lvert f\rvert < \infty$
اعتبار ديريكليه «غير قابلة للتكامل»	قابلة لكن قيمتها 0	ليبيسغ يتعامل معها
نسيان أنّ $\int f = \int f^+ - \int f^-$ يحتاج اندماجاً	قد يخرج $\infty - \infty$	اشترط $\int \lvert f\rvert < \infty$

أمثلة محلولة على تكامل ليبيسغ (15 مثالاً)

مثال (10.5-1).

- **المعطيات:** $f = \mathbf{1}_A$، $\mu(A) = 0.3$.
- **المطلوب:** $\int f\,d\mu$.
- **الحل:**

١. $\int \mathbf{1}_A\,d\mu = \mu(A) = 0.3$. ■

- **النتيجة:** 0.3.
- **الربط بالذكاء الاصطناعي:** «احتمال حدث» = تكامل مؤشّره — التعريف الموحّد للتوقّع.

مثال (5.10-2).

- **المعطيات:** $f = c$ (ثابتة) على A، $\mu(A) = 5$.
- **المطلوب:** $\int_A c \, d\mu$.
- **الحل:**
١. $c \int_A 1 \, d\mu = c\,\mu(A) = 5c$. ■
- **النتيجة:** $5c$.
- **الربط بالذكاء الاصطناعي:** «متوسّط ثابت على منطقة» = القيمة × المساحة — كتلة unfiorm.

مثال (5.10-3).

- **المعطيات:** $\phi = 2\mathbf{1}_{A_1} + 5\mathbf{1}_{A_2}$، $\mu(A_1) = 1, \mu(A_2) = 2$ منفصلتان.
- **المطلوب:** التكامل.
- **الحل:**
١. $2 \cdot 1 + 5 \cdot 2 = 12$. ■
- **النتيجة:** 12.
- **الربط بالذكاء الاصطناعي:** «قيمة متدرّجة لخطوات» — أساس حساب reward expected في التعزيزي.

مثال (5.10-4).

- **المعطيات:** $f(x) = x$ على $[0,1]$ بـ ليبيسغ.
- **المطلوب:** $\int_0^1 x \, dx$ (ليبيسغ).
- **الحل:**
١. بالتقريب البسيط: مساحة المثلث $= 1/2$. ■
- **النتيجة:** $1/2$.
- **الربط بالذكاء الاصطناعي:** «المتوسّط على unfiorm» = 1/2 — معيار مقارنة كل التوزيعات.

مثال (5.10-5).

- **المعطيات:** $f = \mathbf{1}_{\mathbb{Q}}$ (ديريكليه) على $[0,1]$.
- **المطلوب:** $\int_0^1 f \, dx$ ليبيسغ مقابل ريمان.

- **الحل:**

١. ليبيسغ: $\int \mathbf{1}_{\mathbb{Q}} = m(\mathbb{Q}) = 0$.

٢. ريمان: غير موجود (الأعلى 1، الأسفل 0). ■

- **النتيجة:** 0 لليبيسغ؛ ريمان يفشل.

- **الربط بالذكاء الاصطناعي:** «دالة مضطربة لكن متكاملة» — ليبيسغ يمنحنا توقّعاً منطقياً حيث يفشل ريمان.

مثال (10.5-6).

- **المعطيات:** $f = \sum_{k=1}^{\infty} 2^{-k}\mathbf{1}_{\{x_k\}}$ على فضاء منفصل.

- **المطلوب:** $\int f\, d\mu$ (عدّ النقاط).

- **الحل:**

١. النظرية 10.5.1: $\sum_k 2^{-k}\mu(\{x_k\}) = \sum_k 2^{-k} = 1$. ■

- **النتيجة:** 1.

- **الربط بالذكاء الاصطناعي:** «توزيع كثافته نقطية» = مجموع الأوزان — softmax النهائي يُدمج هكذا.

مثال (10.5-7).

- **المعطيات:** $\mu =$ unfiorm على $[0,1]$، $f(x) = e^x$.

- **المطلوب:** $\int_0^1 e^x\, dx$.

- **الحل:**

١. $e^1 - e^0 = e - 1 \approx 1.718$. ■

- **النتيجة:** $e - 1$.

- **الربط بالذكاء الاصطناعي:** «متوسّط دالة أُسّية» — يظهر في توقّع log-likelihood المُسجّل.

مثال (10.5-8).

- **المعطيات:** f, g قابلتا التكامل، $a, b \in \mathbb{R}$.

- **المطلوب:** أثبت الخطيّة (10.4).

- **الحل:**

١. للبسيط: $\int (a\phi + b\psi) = a\sum a_i\mu + b\sum b_i\mu$.

٢. الانتقال للحدّ الأعلى يحفظ الخطيّة. ■

- **النتيجة:** (10.4) محقّقة.

- **الربط بالذكاء الاصطناعي:** «الخسارة الكلّية = مجموع الخسارات» — خطيّة التكامل تبرّر جمع الخسائر على العيّنات.

مثال (10.5-9).

- **المعطيات:** $f \geq 0$، $A \subset B$.
- **المطلوب:** $\int_A f \leq \int_B f$.
- **الحل:**

١. $f\mathbf{1}_A \leq f\mathbf{1}_B \implies$ بالتعريف الأعلى الحدّ أصغر. ■

- **النتيجة:** أحاديّة التوتّر.
- **الربط بالذكاء الاصطناعي:** «خسارة على مجموعة فرعية $\leq$ الكلّية» — أساس تحليل الأخطاء حسب الشريحة.

مثال (10.5-10).

- **المعطيات:** $f = 0$ «تقريباً كل مكان» (a.e.)، أي خارج مجموعة قياسها 0.
- **المطلوب:** $\int f \, d\mu$.
- **الحل:**

١. نعدّل على مجموعة قياس 0 لا تؤثّر في التكامل $\implies$ 0. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «اختلاف على عيّنات معدودة لا يغيّر التوقّع» — سبب إهمال الضجيج النقطي في التقييم.

مثال (10.5-11).

- **المعطيات:** $f(x) = |x|$ على $[-1, 1]$.
- **المطلوب:** التكامل.
- **الحل:**

١. زوجي: $2 \int_0^1 x \, dx = 2 \cdot \frac{1}{2} = 1$. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** «متوسّط القيمة المطلقة» (L1) حول الصفر) — يقابل loss. MAE

مثال (10.5-12).

- **المعطيات:** $f_n = \mathbf{1}_{[0,1/n]}$ على $[0,1]$.
- **المطلوب:** $\int f_n$ و $\lim$ منها.
- **الحل:**

١. $\int f_n = 1/n \to 0$.

٢. النقطة-الحدّ $f_n \to 0$ a.e. $\Longrightarrow$ التكامل يتبع. ■

- **النتيجة:** يصغر إلى 0.
- **الربط بالذكاء الاصطناعي:** «ذيول تتلاشى» — خطأ الذيل $0 \to$ يعني تقارب التقدير.

مثال (10.5-13).

- **المعطيات:** μ احتمال، $0 \le f \le 1$.
- **المطلوب:** حدود $\int f\,d\mu$.
- **الحل:**

١. $0 \le \int f \le \int 1 = 1$. ■

- **النتيجة:** في $[0,1]$.
- **الربط بالذكاء الاصطناعي:** «دقّة نموذج» بين 0 و1 — المتوسّط (التوقّع) داخل نفس الحد.

مثال (10.5-14).

- **المعطيات:** $f(x) = x^2$ على $[0,1]$، قرّبها بسيطة بـ $n = 4$.
- **المطلوب:** قدّر $\int_0^1 x^2 dx$ بالتقريب السفلي.
- **الحل:**

١. صناديق $[0,.25), [.25,.5), \ldots$ قيم سفلية $0, .0625, .25, .5625 \times 25.0 \Longrightarrow$ مجموع 0.21875.

٢. الحقيقي $1/3 \approx 0.333$ (التقريب من الأسفل). ■

- **النتيجة:** 0.219 كحدّ أدنى.
- **الربط بالذكاء الاصطناعي:** «تقدير Carlo Monte سفلي» — أخذ عيّنات يعطي حدوداً أدنى تقارب القيمة.

مثال (10.5-15).

- **المعطيات:** f قابلة للتكامل، $\int |f| = 0$.

- **المطلوب:** استنتج $f = 0$ a.e.
- **الحل:**

١. لو $f \neq 0$ على مجموعة قياس > 0 لكان $\int |f| > 0$.

٢. إذن $f = 0$ a.e. ■

- **النتيجة:** التكامل الصفري $\Longrightarrow$ الانعدام تقريباً كل مكان.
- **الربط بالذكاء الاصطناعي:** «خسارة 0 على التوزيع $\Longrightarrow$ نموذج مثالي» — لكن فقط a.e. (قد يخطئ على مجموعة نادرة).

النظريات

dir="ltr"> <div

Theorem 1.6.10 (Monotone Convergence — MCT). If $0 \le f_1 \le f_2 \le \cdots$ and $f_n \to f$ then a.e.,

$$\lim_{n\to\infty} \int f_n \, d\mu = \int f \, d\mu.$$

Theorem 2.6.10 (Fatou's Lemma). For any sequence $f_n \ge 0$:

$$\int \liminf_n f_n \, d\mu \le \liminf_n \int f_n \, d\mu.$$

Theorem 3.6.10 (Dominated Convergence — DCT). If $|f_n| \le g$ and a.e. $f_n \to f$ with $\int g \, d\mu < \infty$ then

$$\lim_{n\to\infty} \int f_n \, d\mu = \int f \, d\mu.$$

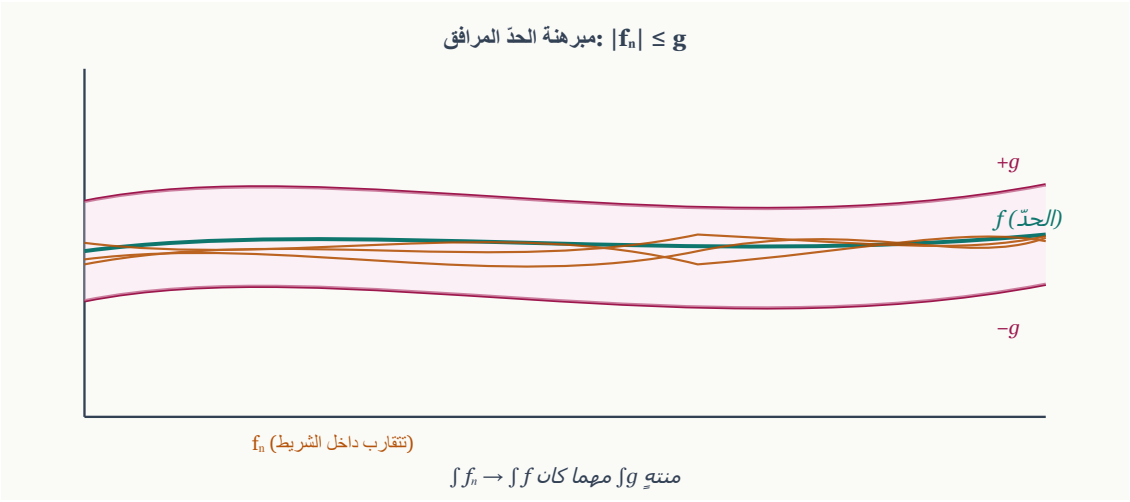
$$\text{DCT: } |f_n| \le g,\ \int g < \infty \implies \int f_n \to \int f. \tag{5.10}$$

جدول الرموز

الرمز	الاسم	المعنى
$f_n \uparrow f$	تقارب رتيب	غير ناقصة نحو f
$\liminf$	الحدّ الأدنى	$\sup_n \inf_{k \ge n}$
g المرافق	دالة الإخضاع	تُغلِّف كل f_n

رسم توضيحي

<figure> الشكل<figcaption> 5.10: مبرهنة الحدّ المرافق — كل f_n محصورة داخل الشريط $[-g, g]$. الحصار بقياس منتهٍ يضمن أنّ تقارب الدوالّ يورث تقارب التكاملات.</figcaption> </figure>



شكل ٥.١٠: *
التقارب المرافق: تسلسل محصور بين ±g

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«الحدّ والتكامل يُتبادلان دائمًا»	بلا شرط ينهار (مثال التنوء المتحرك)	استخدم MCT/DCT
نسيان شرط الإخضاع في DCT	التسلسل قد «يهرب للا نهاية»	$\int g < \infty$ بـ $\lvert f_n \rvert \le g$
Fatou تعطي مساواة	تُعطي فقط $\le$	متراجحة أحاديّة الاتجاه
MCT للدوالّ الموقّعة	تتطلّب غير سالبة	افصل f^+, f^-

أمثلة محلولة على مبرهنات التقارب (15 مثالاً)

مثال (10.6-1).

- **المعطيات:** $\phi_n = \sum_{k=1}^{n} \frac{k-1}{n} \mathbf{1}_{[(k-1)/n,\,k/n)}$ تقارب $f(x) = x$ على $[0,1]$.
- **المطلوب:** استخدم MCT لحساب $\int_0^1 x\,dx$.
- **الحل:**

١. $\phi_n \uparrow x$ غير سالبة.

٢. $\int \phi_n = \frac{n+1}{2n} - \frac{1}{2} \to \frac{1}{2}$. ■

- **النتيجة:** $1/2$.
- **الربط بالذكاء الاصطناعي:** «بناء التوقّع تدريجياً» = MCT — أساس value expected التراكمي.

مثال (10.6-2).

- **المعطيات:** $f_n = n\mathbf{1}_{(0,1/n)}$ على $[0,1]$.

- **المطلوب:** هل ينطبق DCT؟ وما $\lim \int f_n$؟
- **الحل:**

١. $\int f_n = 1$ لكل n لكن $f_n \to 0$ a.e.

٢. لا دالة g منتهية تُغلّفها (الذروة $\to \infty$) $\Longrightarrow$ DCT لا ينطبق. ■

- **النتيجة:** الحدّ 0 لكن التكاملات 1 — لا تبادل.
- **الربط بالذكاء الاصطناعي:** «نتوء متحرك» — تحذير: تبادل الحدّ/التكامل بلا إخضاع يفسد اشتقاق التوقّعات.

مثال (10.6-3).

- **المعطيات:** $f_n(x) = x^n$ على $[0,1]$.
- **المطلوب:** $\lim \int_0^1 x^n dx$ بـ DCT؟
- **الحل:**

١. $|x^n| \le 1$ على $[0,1]$ (قياس 1 منتهٍ) $\Longrightarrow$ DCT.

٢. الحدّ $0 = \mathbf{1}_{\{1\}}$ a.e. $\Longrightarrow$ التكامل $\to 0$. (فعلياً $1/(n+1) \to 0$). ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «تآكل الاحتمال نحو الحافة» — مشابه لتوزّع يتركّز عند نقطة.

مثال (10.6-4).

- **المعطيات:** $f_n = \mathbf{1}_{(n,n+1)}$ على $\mathbb{R}$ بـ ليبيسغ.
- **المطلوب:** Fatou عليها.
- **الحل:**

١. $\liminf f_n = 0$ (كل نقطة خارج كل النطاقات لتكن كبيرة).

٢. $\int f_n = 1 \Longrightarrow 0 \le \liminf 1 = 1$ — Fatou محقّقة بـ $\le$. ■

- **النتيجة:** متراجحة لا مساواة.
- **الربط بالذكاء الاصطناعي:** «كتلة تهاجر للا نهاية» — تذكير أنّ التكاملات قد لا تتقارب رغم صغر كل دالة موضعياً.

مثال (10.6-5).

- **المعطيات:** $f_n \to f$ بلا إخضاع لكن على فضاء قياسه منتهٍ و $|f_n| \le M$.
- **المطلوب:** استنتج DCT مبسّطة.
- **الحل:**

١. $g = M$ ثابتة، $\int g = M\mu(X) < \infty$.

٢. DCT ينطبق. ■

- **النتيجة:** التبادل مضمون.
- **الربط بالذكاء الاصطناعي:** «مخرجات محصورة + بيانات منتهية» ⟹ تبادل آمن — أساس bounded convergence في الشبكات.

مثال (10.6-6).

- **المعطيات:** أعمدة $a_n \ge 0$، $\sum_{n=1}^{\infty} a_n$.
- **المطلوب:** اشتقّ رؤية سلسلة كتكامل عدّي.
- **الحل:**

١. $f_n = \sum_{k=1}^{n} a_k \mathbf{1}_{\{k\}}$، $\uparrow \sum a_k$.

٢. MCT: $\int f_n = \sum_{k=1}^{n} a_k \to \sum a_k$. ■

- **النتيجة:** جمع السلسلة = تكامل.
- **الربط بالذكاء الاصطناعي:** «مجموع خسائر العيّنات = توقّع» — جسر MCT بين السلسلة والتوقّع.

مثال (10.6-7).

- **المعطيات:** f_n تقارب f في L^1: $\int |f_n - f| \to 0$.
- **المطلوب:** استنتج $\int f_n \to \int f$.
- **الحل:**

١. $\left|\int f_n - \int f\right| \le \int |f_n - f| \to 0$. ■

- **النتيجة:** تقارب L^1 يورث تقارب التكامل.
- **الربط بالذكاء الاصطناعي:** «خسارة التدريب تتقارب» (L^1) ⟹ توقّعات التوزيع تتقارب — قياس تقارب المُقدِّر.

مثال (10.6-8).

- **المعطيات:** $f_n(x) = \frac{\sin(nx)}{n}$ على $[0,1]$.
- **المطلوب:** $\lim \int_0^1 f_n$.
- **الحل:**

١. $|f_n| \le 1/n \le 1$، الحدّ 0.

٢. DCT $\Longrightarrow$ التكامل $\to 0$. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «تردّدات سريعة تختفي في التكامل» — مبدأ التذبذب في التحليل الطيفي.

مثال (10.6-9).

- **المعطيات:** $f_n = e^{-nx}$ على $[0,1]$.
- **المطلوب:** $\lim \int_0^1 e^{-nx}dx$.
- **الحل:**

١. لـ $x > 0$: $e^{-nx} \to 0$؛ عند $x = 0$: الحدّ = 1. a.e. $= \mathbf{1}_{\{0\}}$

٢. $|f_n| \le 1 \Longrightarrow$ DCT $\Longrightarrow$ التكامل $\to 0$. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «تلاشٍ أسيّ» — نواة حرارية (dffiusion kernel) تتقارب نحو دلتا، وهنا نحو الصفر.

مثال (10.6-10).

- **المعطيات:** $X_n \to X$ احتمالياً، $|X_n| \le Y$ بـ $\mathbb{E}[Y] < \infty$.
- **المطلوب:** أثبت $\mathbb{E}[X_n] \to \mathbb{E}[X]$.
- **الحل:**

١. هذا DCT بالقياس الاحتمالي (10.5).

٢. $\mathbb{E}[X_n] = \int X_n d\mathbb{P} \to \int X d\mathbb{P} = \mathbb{E}[X]$. ■

- **النتيجة:** تقارب التوقّعات.
- **الربط بالذكاء الاصطناعي:** «نموذج يتقارب احتمالياً + محدود القيمة» $\Longrightarrow$ توقّع خسارته يتقارب — شرط تحليل التعميم.

مثال (10.6-11).

- **المعطيات:** $f_n = \min(f, n)$ لـ $f \geq 0$.
- **المطلوب:** استخدم MCT لإثبات $\int f = \lim \int \min(f, n)$.
- **الحل:**

١. $\min(f, n) \uparrow f$ غير سالبة.

٢. MCT مباشرة. ■

- **النتيجة:** تقارب من الأسفل.

- **الربط بالذكاء الاصطناعي:** «قص القيم المتطرفة تدريجياً» (clipping) يقرّب التكامل الأصلي — clipping في الخسائر.

مثال (10.6-12).

- **المعطيات:** $f_n = n^2 x(1-x)^n$ على $[0, 1]$.
- **المطلوب:** هل $\int f_n \to \int \lim f_n$؟
- **الحل:**

١. الحدّ النقطي 0؛ لكن $\int f_n = n^2 \cdot \frac{1}{(n+1)(n+2)} \to 1 \neq 0$.

٢. لا إخضاع $\Longrightarrow$ DCT لا ينطبق. ■

- **النتيجة:** لا تبادل (مثال مضادّ).

- **الربط بالذكاء الاصطناعي:** حتى مع «اختفاء نقطي» قد يبقى تكامل متبقّ — حذر في اشتقاق التوقّعات التبادلية.

مثال (10.6-13).

- **المعطيات:** سلسلة دوالّ $f_n \geq 0$ بـ $\int f_n \leq C$.
- **المطلوب:** نتيجة Fatou.
- **الحل:**

١. $\int \liminf f_n \leq \liminf \int f_n \leq C$. ■

- **النتيجة:** الحدّ الأدنى محصور.

- **الربط بالذكاء الاصطناعي:** «الخسارة الكلّية محدودة» $\Longrightarrow$ الحدّ الأدنى للخسارة محدود — ضمان عدم انفجار التدريب.

مثال (10.6-14).

- **المعطيات:** $f_n(x) = \frac{n}{1+n^2x^2}$ (نواة بواسون) على $\mathbb{R}$.
- **المطلوب:** سلوك $\int_{-\infty}^{\infty} f_n dx$.
- **الحل:**

١. بتعويض $u = nx$: التكامل $= \int \frac{1}{1+u^2} du = \pi$ لكل n (ثابت!).

٢. الحدّ النقطي 0 لكن التكامل $\pi \Longrightarrow$ لا DCT (لا إخضاع منتهٍ). ■

- **النتيجة:** تقارب ضعيف نحو دلتا ديراك (كتلة بلا عرض).
- **الربط بالذكاء الاصطناعي:** «نواة تقارب نحو delta» — أساس الـ reparameterization والتوزيعات الانتقالية في dffiusion.

مثال (10.6-15).

- **المعطيات:** توزيع احتمالي $P_n \to P$ بالتقارب الضعيف، دالة h مستمرّة محدودة.
- **المطلوب:** استنتج $\int h\, dP_n \to \int h\, dP$.
- **الحل:**

١. h محدودة $\Longrightarrow$ إخضاع بثابت؛ تعريف/DCT التقارب الضعيف.

٢. $\mathbb{E}_{P_n}[h] \to \mathbb{E}_P[h]$. ■

- **النتيجة:** تقارب التوقّعات.
- **الربط بالذكاء الاصطناعي:** «توزيع المخرجات يتقارب $\Longrightarrow$ مقاييسها تتقارب» — أساس تقييم نموذج توليدي (FID يستخدم توقّعات).

التعريف

dir="ltr"> <div

Definition 10.7.1 (Lebesgue–Stieltjes integral). Let $F : \mathbb{R} \to \mathbb{R}$ be increasing and right-continuous. It defines a measure μ_F by

$$\mu_F\big((a, b]\big) = F(b) - F(a).$$

The **Lebesgue–Stieltjes integral** of h is

$$\int h(x)\, dF(x) := \int h(x)\, d\mu_F(x).$$

function, step a is F fi ;$dF = F'(x)dx$ continuous, absolutely is F If

$$\int h\,dF = \sum_i h(x_i)\,\Delta F_i, \quad \Delta F_i = F(x_i) - F(x_i^-).$$

$$\int h\,dF = \sum_i h(x_i)\Delta F_i \text{ (discrete)}, \qquad \int h(x)F'(x)\,dx \text{ (smooth)}. \tag{6.10}$$

النظرية 1.7.10 (خصائص):

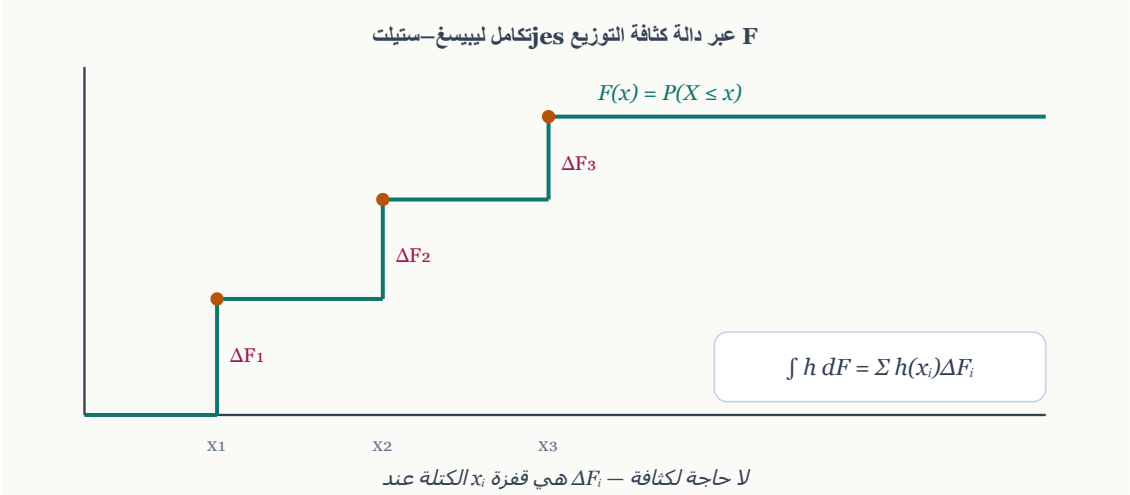
- **الخطيّة:** $\int (ah + bg)dF = a\int h\,dF + b\int g\,dF$.
- **التكامل بالأجزاء:** $\int_a^b h\,dF = h(b)F(b) - h(a)F(a) - \int_a^b F\,dh$.
- **دلتا ديراك:** إذا F قفزة عند c فقط، $\int h\,dF = h(c)$.

جدول الرموز

الرمز	الاسم	المعنى
F	دالة كثافة التوزيع (CDF)	$F(x) = P(X \le x)$
μ_F	القياس المرافق	كتلته = قفزات F
dF	الإجراء (measure element)	$F'(x)dx$ أو $\sum \Delta F_i \delta_{x_i}$

رسم توضيحي

<figure> الشكل<figcaption>6.10: $F(x) = P(X \le x)$ دالة صاعدة؛ تكامل h بالنسبة لـ dF هو مجموع $h(x_i)$



شكل ٦.١٠: *
تكامل ستيلتjes ككتل عند قفزات CDF

مضروباً في ارتفاع القفزة ΔF_i عند كل نقطة. لا حاجة لكثافة — يعمل للتوزيعات المختلطة.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الخلط dF مع $F\,dx$	dF إجراء لا دالة	اكتب القياس صراحة
نسيان القفزات في المنفصل	المرء يدمج فقط الكثافة	أضف $\sum h(x_i)\Delta F_i$
«Stieltjes = ريمان-ستيلتjes فقط»	ليبيسغ-ستيلتjes أعمّ	التكامل على μ_F
تجاهل الاستمرار يميناً	شرط تعريف القياس	F يمين-مستمرة دائماً

أمثلة محلولة على تكامل ليبيسغ–ستيلتjes (15 مثالاً)

مثال (10.7-1).

- **المعطيات:** $F(x) = \mathbf{1}_{[0,\infty)}(x)$ (قفزة عند 0 بارتفاع 1).
- **المطلوب:** $\int h\,dF$.
- **الحل:**

١. $\Delta F_0 = 1$ عند $x = 0$، باقي الصفر.

٢. $\int h\,dF = h(0)$. ■

- **النتيجة:** $h(0)$ — دلتا ديراك.
- **الربط بالذكاء الاصطناعي:** «توزيع منفصل عند نقطة» = دلتا — يظهر في الأهداف الحتمية (hard labels).

مثال (10.7-2).

- **المعطيات:** $F(x) = x$ على $[0,1]$ (unfiorm).
- **المطلوب:** $\int_0^1 x\,dF(x)$.
- **الحل:**

١. $F'(x) = 1 \Longrightarrow \int_0^1 x \cdot 1\,dx = 1/2$. ■

- **النتيجة:** $\mathbb{E}[X] = 1/2$ لـ unfiorm.
- **الربط بالذكاء الاصطناعي:** «التوقّع تحت unfiorm — معيار المقارنة لأيّ توزيع.

مثال (10.7-3).

- **المعطيات:** X بقيم $\{1,2,3\}$ واحتمالات $0.2, 0.3, 0.5$.
- **المطلوب:** $\mathbb{E}[X] = \int x\,dF$.
- **الحل:**

١. $\Delta F_1 = 0.2, \Delta F_2 = 0.3, \Delta F_3 = 0.5$.

٢. $1(0.2) + 2(0.3) + 3(0.5) = 0.2 + 0.6 + 1.5 = 2.3$. ■

- **النتيجة:** 2.3.
- **الربط بالذكاء الاصطناعي:** «توقّع منفصل» = مجموع قيم×احتمالات — تماماً ما يحسبه softmax×logits.

مثال (10.7-4).

- **المعطيات:** $F(x) = 1 - e^{-\lambda x}$ لـ $x \geq 0$ (أسّي).
- **المطلوب:** $\mathbb{E}[X] = \int x\, dF$.
- **الحل:**

١. $F'(x) = \lambda e^{-\lambda x}$.

٢. $\int_0^\infty x\lambda e^{-\lambda x} dx = 1/\lambda$. ■

- **النتيجة:** $1/\lambda$.
- **الربط بالذكاء الاصطناعي:** «المتوسّط الأسّي» — يظهر في أوقات الخدمة/الانتظار ومعدّلات التعرّف.

مثال (10.7-5).

- **المعطيات:** F تقفز عند $x_1 = 0$ (0.5) و $x_2 = 1$ (0.5).
- **المطلوب:** $\int x^2\, dF$.
- **الحل:**

١. $0^2(0.5) + 1^2(0.5) = 0.5$. ■

- **النتيجة:** 0.5.
- **الربط بالذكاء الاصطناعي:** «توزيع مزدوج النقاط» — نموذج لـ mixture of two outcomes.

مثال (10.7-6).

- **المعطيات:** $h(x) = e^{tx}$، F توزيع X.
- **المطلوب:** عرّف الدالة المولّدة للحظة $M(t) = \int e^{tx} dF$.
- **الحل:**

١. $M(t) = \mathbb{E}[e^{tX}]$ — تحوّل لابلاس.

٢. مشتقّتها عند 0 تعطي اللحظات. ■

- **النتيجة:** $M(t)$ العامل المولّد.
- **الربط بالذكاء الاصطناعي:** «اللحظات عبر التفاضل» — أساس تقدير إحصاء اللحظات وتنظيم التوزيعات.

مثال (10.7-7).

- **المعطيات:** توزيع مختلط: كتلة 0.7 عند 0 و unfiorm على $(0,1)$ بكتلة 0.3.
- **المطلوب:** $\mathbb{E}[X]$ بـ Stieltjes.
- **الحل:**

١. القفزة: $0 \cdot 0.7 = 0$؛ المستمرّ: $0.3 \int_0^1 x\,dx = 0.3(0.5) = 0.15$.

٢. المجموع 0.15. ■

- **النتيجة:** 0.15.
- **الربط بالذكاء الاصطناعي:** «توزيع مختلط» discrete-continuous — تماماً ما يصف بيانات بقيم مفقودة عند الصفر + مستمرّ.

مثال (10.7-8).

- **المعطيات:** F تقفز بـ $\Delta F_i = 1/n$ عند كل نقطة بيانات x_i (التوزيع التجريبي).
- **المطلوب:** $\int h\,dF_n$ (المتوسّط التجريبي).
- **الحل:**

١. $\sum_i h(x_i) \cdot \frac{1}{n} = \frac{1}{n}\sum h(x_i)$. ■

- **النتيجة:** متوسّط العيّنات.
- **الربط بالذكاء الاصطناعي:** «التوقّع التجريبي = متوسّط العيّنات» — الجسر بين loss train و risk، expected.

مثال (10.7-9).

- **المعطيات:** $\int_a^b h\,dF$ مع F يمين-مستمرة.
- **المطلوب:** صيغة التكامل بالأجزاء (النظرية 10.7.1).
- **الحل:**

١. $\int_a^b h\,dF = h(b)F(b) - h(a)F(a) - \int_a^b F\,dh$. ■

- **النتيجة:** صيغة Stieltjes.
- **الربط بالذكاء الاصطناعي:** «تبادل التكامل» هذا يُستخدم في اشتقاق ELBO وتحليل التباين.

مثال (10-7.10).

- **المعطيات:** $F(x) = \Phi(x)$ (توزيع طبيعي معياري).
- **المطلوب:** $\int x \, d\Phi(x)$.
- **الحل:**

١. الكثافة $\phi(x)$ متماثلة حول 0.

٢. $\int x\phi(x)dx = 0$. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «توقّع التوزيع المتناظر = 0» — مركزية الـ Gaussian حول mean.

مثال (11-7.10).

- **المعطيات:** $F_\theta(x)$ تتغيّر بارامتر θ، احسب $\frac{d}{d\theta}\int h \, dF_\theta$.
- **المطلوب:** اشتقّ عبر التوزيع.
- **الحل:**

١. $\frac{d}{d\theta}\int h \, dF_\theta = \int h \, \frac{dF_\theta}{d\theta}$ (تبادل اشتقاق/تكامل مبرّر بـ DCT). ■

- **النتيجة:** مشتقّة التوقّع.
- **الربط بالذكاء الاصطناعي:** «تدرّج التوقّع حسب المعاملات» — أساس gradient policy و score function estimator.

مثال (12-7.10).

- **المعطيات:** توزيعان F, G، وزن $\lambda \in [0,1]$، عرّف $H = \lambda F + (1-\lambda)G$.
- **المطلوب:** $\int h \, dH$.
- **الحل:**

١. خطيّة Stieltjes: $\lambda \int h \, dF + (1-\lambda)\int h \, dG$. ■

- **النتيجة:** خليط (mixture).
- **الربط بالذكاء الاصطناعي:** «نموذج خليط غاوسي» (GMM) — توقّعه مجموع موزون لتوقّعات المكوّنات.

مثال (10.7-13).

- **المعطيات:** F القفزات عند x_i بـ p_i؛ احسب $\int (x-\mu)^2 dF$ (التباين).
- **المطلوب:** التباين.
- **الحل:**

١. $\sum_i (x_i-\mu)^2 p_i$ (الصيغة المنفصلة الكلاسيكية). ■

- **النتيجة:** التباين المنفصل.
- **الربط بالذكاء الاصطناعي:** «التباين = تكامل $(x-\mu)^2$» — كل مقاييس التشتّت (variance) تصيغها Stieltjes.

مثال (10.7-14).

- **المعطيات:** $F(x)=x^2$ على $[0,1]$ (توزيع بكثافة $2x$).
- **المطلوب:** $\mathbb{E}[X]=\int x\,dF$.
- **الحل:**

١. $F'(x)=2x \Rightarrow \int_0^1 x\cdot 2x\,dx = 2/3$. ■

- **النتيجة:** $2/3$.
- **الربط بالذكاء الاصطناعي:** «توزيع منحاز نحو 1» (كثافة متزايدة) — نموذج لـ bias preference في البيانات.

مثال (10.7-15).

- **المعطيات:** KL عبر Stieltjes: $D_{KL}(P\|Q)=\int \ln \frac{dP}{dQ}\,dP$.
- **المطلوب:** عبّر KL المنفصل والستيلتjes.
- **الحل:**

١. المنفصل: $\sum_i p_i \ln(p_i/q_i)$.

٢. العامّ: $\int \ln \frac{d\mu_P}{d\mu_Q}\,d\mu_P$ (مشتقّ رادون–نيكوديم). ■

- **النتيجة:** KL الموحّد.
- **الربط بالذكاء الاصطناعي:** «كل خسارة تشابه توزيعي (KL, JS, cross-entropy) هي تكامل Stieltjes» — الجسر إلى الفصل 26 (نظرية المعلومات) والـ ELBO في VAE.

خيط الفصل

١. **فضاء القياس (1.10)** يمنحنا «حجم الحدث» $\mu(A)$ — أساس كل احتمال.

٢. **قياس ليبيسغ (2.10)** يحلّ محلّ طول ريمان ويتعامل مع القفزات والمجموعات الشاذة.

٣. **الدوال القياسية (3.10)** تضمن أنّ كل مخرجات الشبكة «مرئية» للتكامل.

٤. **تكامل ليبيسغ (4.10)** يعرّف $\int f\,d\mu$ كحدّ أعلى لدوالّ بسيطة — ويشمل ديريكليه.

٥. **مبرهنات التقارب (5.10)** هي «رخصة تبادل الحدّ والتكامل». (MCT/Fatou/DCT)

٦. **ليبيسغ–ستيلتjes (6.10)** يربط F (CDF) بالتوقّع $\int h\,dF$ = أساس الإحصاء كله.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
$(\Omega, \mathcal{F}, \mathbb{P})$	كل نظرية الاحتمال (الفصل 13+)
$\int X\,d\mathbb{P} = \mathbb{E}[X]$	التوقّع والمخاطرة المتوقّعة
MCT / DCT	تبادل الحدّ والتكامل في التقارب
$\int h\,dF$	توقّع، ELBO، KL $\to$ CDF
التوزيع التجريبي	الجسر risk expected$\to$train (الفصل 30)
Radon–Nikodym	تغيير القياس في sampling importance / RL

١. أثبت أنّ $\mathcal{F} = 2^\Omega$ σ-جبرا لأيّ مجموعة منتهية Ω.

٢. لـ $A_n \uparrow A$ مع $\mu(A_1) < \infty$، أثبت $\mu(A) = \lim \mu(A_n)$ باستخدام القابلية العدّية.

٣. احسب $m(\{1/n : n \in \mathbb{N}\})$ على $\mathbb{R}$ بـ قياس ليبيسغ.

٤. بيّن أنّ مجموعة كانتور قياسها 0 مع أنّها غير عدّية.

٥. هل اتحاد σ-جبرتين دائماً σ-جبرا؟ اذكر مثالاً مضادّاً.

٦. أثبت أنّ f قياسية $\iff \{x : f(x) > a\} \in \mathcal{F}$ لكل a.

٧. لـ f, g قياسيتان، أثبت قياس $\max(f,g)$ و $\min(f,g)$.

٨. قرّب $f(x) = x^2$ على $[0,1]$ بدوالّ بسيطة $\phi_n \uparrow f$ واستنتج $\int_0^1 x^2 dx$.

٩. احسب $\int_{[0,1]} \mathbf{1}_{\mathbb{Q}}\,dx$ (ليبيسغ) وفسّر فرقها عن ريمان.

١٠. استخدم MCT لإثبات $\sum_{k=1}^{\infty} a_k = \int (\sum a_k \mathbf{1}_{\{k\}}) d\mu$ لـ $a_k \geq 0$.

١١. لـ $f_n = n\mathbf{1}_{(0,1/n)}$، بيّن لماذا لا ينطبق DCT وما $\lim \int f_n$.

١٢. طبّق Fatou على $f_n = \mathbf{1}_{(n,n+2)}$ على $\mathbb{R}$ وحدّد $\liminf \int f_n$.

١٣. أثبت أنّ $\int f_n \to \int f \implies \int |f_n - f| \to 0$.

١٤. لـ $F(x) = \mathbf{1}_{[a,\infty)}(x)$، احسب $\int h\,dF$ (دلتا عند a).

١٥. distribution منفصل $\{x_1, \dots, x_k\}$ باحتمالات p_i، اشتقّ $\mathrm{Var}(X) = \int (x-\mu)^2 dF$ كمجموع.

١٦. لـ $F(x) = 1 - e^{-x}$ $(x \geq 0)$، احسب $\mathbb{E}[X]$ و $\mathbb{E}[X^2]$ بالتكامل Stieltjes.

١٧. برهن خطيّة تكامل Stieltjes: $\int (ah + bg) dF = a\int h\,dF + b\int g\,dF$.

١٨. التوزيع التجريبي F_n بنقاط $\{x_i\}$ أوزان $1/n$؛ أثبت $\int h\,dF_n = \frac{1}{n}\sum h(x_i)$.

١٩. عبّر KL المنفصل $D_{KL}(P\|Q)$ كتكامل Stieltjes، واربطه بالتوقّع $\mathbb{E}_P[\ln(p/q)]$.

٢٠. تحدٍّ تركيبي: «لماذا risk expected = متوسّط الخسارة؟» — ابنِ F_n التجريبي من عيّنات، واستنتج $\int L\,dF_n = \frac{1}{n}\sum L(x_i)$، ثم اشرح متى يتقارب مع $\int L\,d\mathbb{P}$ (استخدم DCT أو تقارب ضعيف).

- **القياس (1.10):** $(\Omega, \mathcal{F}, \mu)$ بقابلية جمع عدّية، $\mu(\emptyset) = 0$ والاستمرارية من الأسفل/الأعلى.
- **ليبيسغ (2.10):** $m([a,b]) = b - a$، ثبات الترجمة والتجانس، والمجموعات العدّية (وحتى كانتور) قياسها 0.
- **القياسيّة (3.10):** f قياسية $\iff$ صورة كل بوريل عكسياً قياسية؛ كل f تُقرَّب بسيطة $\phi_n \uparrow f$.
- **التكامل (4.10):** $\int f\,d\mu = \sup$ على البسيطات؛ خطّي، يدمج ديريكليه بقيمة 0.
- **التقارب (5.10):** MCT (رتيب غير سالب)، Fatou ($\leq$)، DCT (محصور بـ g منتهية).
- **Stieltjes (6.10):** $\int h\,dF = \sum h(x_i)\Delta F_i$ (منفصل) أو $\int hF'dx$ (سلس)؛ الجسر إلى $\mathbb{E}[X]$ و KL.

الرمز	المعنى	أين عُرّف
$(\Omega, \mathcal{F}, \mu)$	فضاء القياس	(1.10)
$m(E)$	قياس ليبيسغ	(2.10)
$\mathbf{1}_A$	دالة المؤشّر	(3.10)
$\int f\,d\mu$	تكامل ليبيسغ	(4.10)
$f_n \uparrow f$	تقارب رتيب	نظرية 1.6.10
$\int h\,dF$	ليبيسغ–ستيلتjes	(6.10)
μ_F	القياس المرافق لـ F	(7.10)

١. W. Rudin, (1987). *Real and Complex Analysis*, 3rd ed., McGraw-Hill — المرجع الكنسي لنظرية القياس وتكامل ليبيسغ.

٢. G. Folland, (1999). *Real Analysis: Modern Techniques and Their Applications*, 2nd ed., Wiley — σ-جبرات، قياس ليبيسغ، ومبرهنات التقارب.

٣. P. Billingsley, (1995). *Probability and Measure*, 3rd ed., Wiley — الربط بين القياس والاحتمال والتكامل Stieltjes.

٤. S. Lahiri, & K. Athreya, (2006). *Measure Theory and Probability*, Springer — مقدمة لطيفة بأمثلة إحصائية.

٥. D. Cohn, (2013). *Measure Theory*, 2nd ed., Birkhäuser — تفاصيل σ-جبرا المولّدة والقياسات.

٦. T. Tao, (2011). *An Introduction to Measure Theory*, AMS — عرض حديث واضح للمبتدئين المتقدّمين.

٧. I., Goodfellow, Y. Bengio, & A. Courville (2016). *Deep Learning*, MIT Press (الفصل 3: التوزيعات والتوقّع كتكامل) — استخدامات ML المباشرة.

٨. K. Murphy, (2022). *Probabilistic Machine Learning*, MIT Press — التوقّعات والـ KL والتوزيع التجريبي في السياق التطبيقي.

متفاضلة تايلور وتحليل الأخطاء

الهدف من الفصل

خامس فصول الجزء الثاني (التفاضل والتكامل). أنهينا النهايات (7) والمشتقّة (8) والتفاضل المصفوفي (9) والتكامل/القياس (10). الآن نربط الاشتقاق بالتقريب: «كلّ ما لا نستطيع حسابه بدقّة نقرّبه بتايلور، وكلّ تقريب له خطأ نحلّله». الانحدار (gradient descent) هو تايلور من الدرجة الأولى؛ ونيوتن (Newton) هو تايلور من الدرجة الثانية؛ والتفاضل الآلي (autodffi) يحسب معاملات تايلور بدقّة.

أربعة أسباب تجعل هذا الفصل حجر الزاوية في الذكاء الاصطناعي:

١. **النماذج محليّاً متعدّدة حدود:** حول أيّ نقطة، $f(x+h) \approx f + \nabla^\top h + \frac{1}{2} h^\top \nabla^2 f\, h$. هذا يبرّر لماذا نعتمد التدرّج (الدرجة 1) ونيوتن (الدرجة 2).

٢. **التفاضل الآلي = معاملات تايلور:** backprop يحسب اليعقوبية والهِسّية — أيّ معاملات التوسّع — بدقّة رياضية لا تقريب فرقُ منتهٍ.

٣. **تحليل الأخطاء:** قطع السلسلة يُنتج «خطأ قطع» (truncation)؛ وانتشار الخطأ عبر طبقات الشبكة يُنتج «تكيّفاً سيّئاً» (ill-conditioning) — امتداد مباشر للفصل 6 (الاستقرار العددي).

٤. **التعلّم الحديث:** نيوتن، Natural Gauss-Newton، Gradient انتشار لانغفين (Langevin)، ومبرهنة Tweedie في dffiusion كلها صيغت بتايلور.

خريطة الفصل

القسم	الموضوع	الأداة المركزية
2.11	متسلسلة ومتعدّدات تايلور	$P_n(x)$
3.11	صيغ البقايا (Peano/تكاملي/Lagrange)	$R_n(x)$
4.11	تايلور متعدّد المتغيّرات	∇, ∇^2
5.11	خطأ القطع والتقارب	$O(h^{p+1})$
6.11	انتشار الخطأ والتكيّف	$\kappa(x)$
7.11	التطبيقات في الذكاء الاصطناعي	نيوتن/autodffi/Gauss-Newton

التعريف

dir="ltr"> <div

Definition 1.2.11 (Taylor polynomial). Let $f \in C^n$ near a. The **Taylor n-th** of f about a is **polynomial**

$$P_n(x) = \sum_{k=0}^{n} \frac{f^{(k)}(a)}{k!}(x-a)^k. \tag{1.11}$$

dir="ltr"> <div
$a = 0$ About .f of **series Taylor** the is limit the interval, an on $n \to \infty$ as $P_n(x) \to f(x)$ If .**series Maclaurin** the called is it

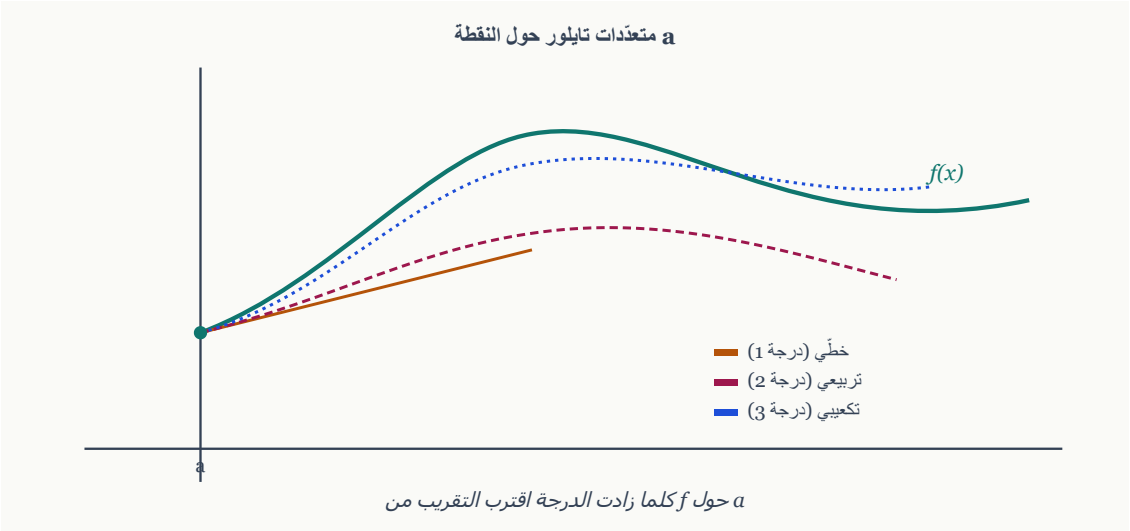
النظرية 1.2.11 (صيغ كلاسيكية): $(1+x)^\alpha = ,\sin x = \sum(-1)^k x^{2k+1}/(2k+1)!\ ,e^x = \sum x^k/k!$ $.1/(1-x) = \sum x^k\ ,\sum \binom{\alpha}{k} x^k$

جدول الرموز

الرمز	الاسم	المعنى
P_n	متعدّدة تايلور	تقريب حدّي الدرجة n
$f^{(k)}$	المشتقّة k	معامل الحدّ k
a	مركز التوسّع	نقطة التقارب المحلّي

رسم توضيحي

<figure> الشكل<figcaption> 1.11: حول a، الخطّ المستقيم (درجة 1) ثمّ التربيعي (2) ثمّ التكعيبي (3) يلتفّون



a حول f كلما زادت الدرجة اقترب التقريب من

شكل ١.١١: *
متعدّدات تايلور من الدرجات 1 و2 و3

حول f. كلّما زادت الدرجة اقترب التقريب — محليّاً على الأقلّ.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«تايلور يتقارب دائماً»	قد تفشل السلسلة خارج نصف القطر	افحص نصف القطر
خلط $(x-a)$ مع x	المركز a أساسيّ	استخدم $(x-a)$ دائماً
نسيان العامل $k!$	معاملات خاطئة	اقسم على العاملي
اعتبار P_n تقريباً عالمياً	هو محليّ حول a	«قرب a» شرط صريح

أمثلة محلولة على متسلسلة ومتعدّدات تايلور (15 مثالاً)

مثال (11.2-1).

- **المعطيات:** $f(x) = e^x$ حول $a = 0$.
- **المطلوب:** اكتب $P_3(x)$.
- **الحل:**

١. $f^{(k)}(0) = 1$ لكل k.

٢. $P_3 = 1 + x + \frac{x^2}{2} + \frac{x^3}{6}$. ■

- **النتيجة:** $1 + x + x^2/2 + x^3/6$.
- **الربط بالذكاء الاصطناعي:** «تقريب exp بخطوات» — أساس تثبيت softmax العددي (log-sum-exp من الفصل 6).

مثال (11.2-2).

- **المعطيات:** $f(x) = \sin x$ حول 0.
- **المطلوب:** $P_5(x)$.
- **الحل:**

١. المشتقّات بالتناوب $1, 0, -1, 0, 1, 0$ عند 0.

٢. $P_5 = x - \frac{x^3}{6} + \frac{x^5}{120}$. ■

- **النتيجة:** الحدود الفردية فقط.
- **الربط بالذكاء الاصطناعي:** «تقريب زاوية صغيرة» $\sin x \approx x$ يُستخدم في دوران الكاميرا والفيزياء المحاكاة.

مثال (11.2-3).

- **المعطيات:** $f(x) = \cos x$ حول 0.
- **المطلوب:** $P_4(x)$.
- **الحل:**

١. المشتقّات $0, -1, 0, 1, 0$.

٢. $P_4 = 1 - \frac{x^2}{2} + \frac{x^4}{24}$. ■

- **النتيجة:** الحدود الزوجية.
- **الربط بالذكاء الاصطناعي:** «تقريب التغيير الطفيف» $\cos x \approx 1 - x^2/2$ في تنعيم الإشارات.

مثال (11.2-4).

- **المعطيات:** $f(x) = \ln(1+x)$ حول 0.
- **المطلوب:** $P_3(x)$ ونصف القطر.
- **الحل:**

١. $f'(0) = 1,\ f''(0) = -1,\ f'''(0) = 2$.

٢. $P_3 = x - \frac{x^2}{2} + \frac{x^3}{3}$؛ نصف القطر $= 1$ (متفرّع عند $x = -1$). ■

- **النتيجة:** سلسلة متناوبة.
- **الربط بالذكاء الاصطناعي:** «تقريب log(1+x) صغير» يُستخدم في خسارة السجلّ (log-loss) حول الصفر.

مثال (11.2-5).

- **المعطيات:** $f(x) = (1+x)^{\alpha}$ حول 0.
- **المطلوب:** أوّل ثلاثة حدود (ذات الحدّين العامّ).
- **الحل:**

١. $f'(0) = \alpha,\ f''(0) = \alpha(\alpha-1)$.

٢. $1 + \alpha x + \frac{\alpha(\alpha-1)}{2}x^2 + \cdots$. ■

- **النتيجة:** معاملات ذات الحدّين.
- **الربط بالذكاء الاصطناعي:** «تقريب القوى» لمشتقّات w.r.t. معاملات في بايز السلس (Laplace approximation).

مثال (11.2-6).

- **المعطيات:** $f(x) = \frac{1}{1-x}$ حول 0.
- **المطلوب:** السلسلة ونصف القطر.
- **الحل:**

١. مشتقّات: $f^{(k)}(0) = k!$.

٢. $\sum_{k=0}^{\infty} x^k$؛ نصف القطر 1. ■

- **النتيجة:** هندسية.
- **الربط بالذكاء الاصطناعي:** «جمع هندسي» = قيمة خصم المكافآت في التعزيزي $\sum \gamma^k$.

مثال (11.2-7).

- **المعطيات:** $f(x) = \arctan x$ حول 0.
- **المطلوب:** $P_3(x)$.
- **الحل:**

١. $f'(0) = 1,\ f'''(0) = -2$.

٢. $x - \frac{x^3}{3}$. ■

- **النتيجة:** متناوبة فردية.
- **الربط بالذكاء الاصطناعي:** «تقريب الزاوية» في تقدير الاتجاه من الميل.

مثال (11.2-8).

- **المعطيات:** $\sinh x, \cosh x$ حول 0.
- **المطلوب:** السلسلتان.
- **الحل:**

١. $\sinh x = x + \frac{x^3}{6} + \cdots$؛ $\cosh x = 1 + \frac{x^2}{2} + \cdots$. ■

- **النتيجة:** فردية/زوجية منفصلة.
- **الربط بالذكاء الاصطناعي:** «دوالّ القطع الزائدي» تظهر في sinh-acceleration والشبكات بـ swish.

مثال (11.2-9).

- **المعطيات:** e^{ix} حول 0.
- **المطلوب:** اشتقّ صيغة أويلر.
- **الحل:**

١. $P = \sum (ix)^k/k! = \big(\sum (-1)^k x^{2k}/(2k)!\big) + i\big(\sum (-1)^k x^{2k+1}/(2k+1)!\big)$.

٢. $= \cos x + i \sin x$. ■

- **النتيجة:** $e^{ix} = \cos x + i \sin x$.
- **الربط بالذكاء الاصطناعي:** «الترميز الموضعي» (positional encoding) في المحوّلات يستخدم $\sin$ / $\cos$ — جذورها من أويلر.

مثال (10-2.11).

- **المعطيات:** قرّب $\sqrt{1.1}$ بـ $(1+x)^{1/2}$ عند $x = 0.1$.
- **المطلوب:** تقدير بدرجة 2.
- **الحل:**

١. $1 + \frac{1}{2}(0.1) - \frac{1}{8}(0.1)^2 = 1 + 0.05 - 0.00125 = 1.04875$. ■

- **النتيجة:** $1.0488 \approx$ (الحقيقي 1.0488).
- **الربط بالذكاء الاصطناعي:** «تقريب الجذر» لتطبيع الأوزان (weight normalization).

مثال (11-2.11).

- **المعطيات:** قرّب $e^{0.1}$ بدرجة 3.
- **المطلوب:** القيمة.
- **الحل:**

١. $1 + 0.1 + 0.005 + 0.0001667 = 1.1051667$. ■

- **النتيجة:** ≈ 1.10517.
- **الربط بالذكاء الاصطناعي:** «تقريب exp صغير» في حساب الاحتمالات اللحظية.

مثال (12-2.11).

- **المعطيات:** $f(x) = \ln \frac{1+x}{1-x}$ حول 0.
- **المطلوب:** P_3.
- **الحل:**

١. $\ln(1+x) - \ln(1-x) = (x - x^2/2 + x^3/3) - (-x - x^2/2 - x^3/3) = 2x + 2x^3/3$. ■

- **النتيجة:** $2x + \frac{2}{3}x^3$.
- **الربط بالذكاء الاصطناعي:** «دالة atanh» تُستخدم في ربط القيم المستمرّة (Gumbel/Concrete relaxation).

مثال (13-2.11).

- **المعطيات:** $f(x) = x^3$ حول $a = 2$.

- **المطلوب:** $P_3(x)$ (يجب أن تساوي f تماماً).
- **الحل:**

١. $f(2)=8,\ f'(2)=12,\ f''(2)=12,\ f'''(2)=6$.

٢. $8+12(x-2)+6(x-2)^2+(x-2)^3=x^3$ (تحقّق بالفكّ). ■

- **النتيجة:** متطابقة — متعدّدة حدود = تايلور اللانهائي.
- **الربط بالذكاء الاصطناعي:** «أيّ متعدّدة حدود هي تايلورها» — أساس تمثيل كثيرات الحدود في الطبقات.

مثال (11.2-14).

- **المعطيات:** e^x، نصف القطر ؟ $=$
- **المطلوب:** أثبت التقارب لكلّ x.
- **الحل:**

١. نصف القطر $=\lim|a_k/a_{k+1}|=\infty$. ■

- **النتيجة:** سلسلة كاملة (entire).
- **الربط بالذكاء الاصطناعي:** «لا حدود تقارب» $\Longrightarrow$ تقريب exp موثوق لأيّ مقياس — سبب استقراره العددي.

مثال (11.2-15).

- **المعطيات:** عيّنات (x_i,y_i)، استيفاء متعدّد حدود درجة n.
- **المطلوب:** اربطه بتايلور.
- **الحل:**

١. الاستيفاء يمرّ بالنقاط؛ تايلور يمرّ بالمشتقّات عند a — كلاهما «تحديد متعدّدة بـ $n+1$ معامل». ■

- **النتيجة:** وجهان لنفس البناء.
- **الربط بالذكاء الاصطناعي:** «استيفاء البيانات» = تركيب متعدّدة تقرّب العيّنات — نواة كل انحدار كثير الحدود.

التعريف

dir="ltr"> <div

forms: Three .$R_n(x) = f(x) - P_n(x)$ **(Remainder). 1.3.11 Definition**

- **Lagrange:** $R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}(x-a)^{n+1}$ for some $\xi \in (a,x)$.
- **Integral:** $R_n(x) = \int_a^x \frac{f^{(n+1)}(t)}{n!}(x-t)^n\,dt$.
- **Peano:** $R_n(x) = o\big((x-a)^n\big)$.

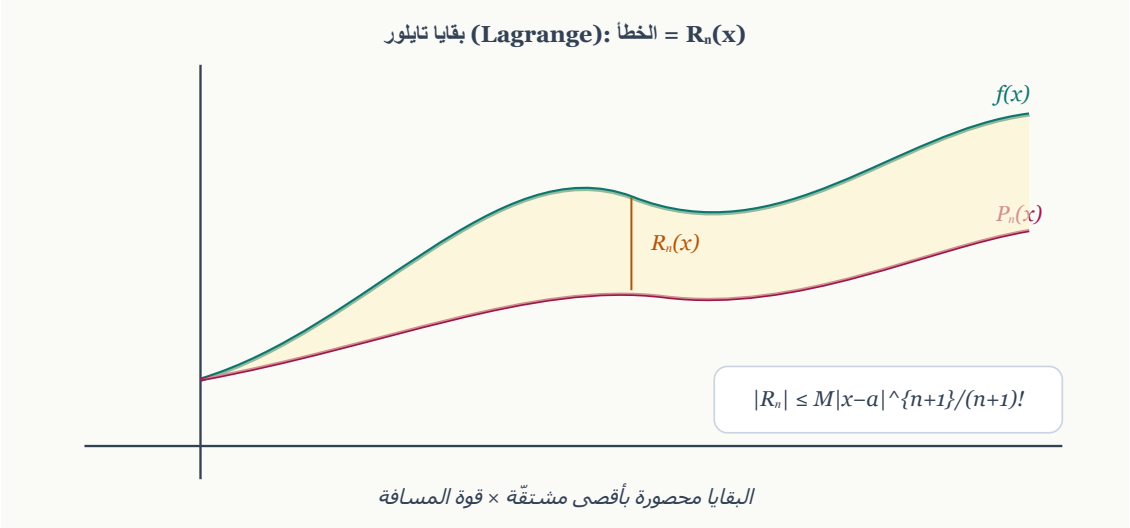
$$|R_n(x)| \le \frac{M}{(n+1)!}\,|x-a|^{n+1}, \quad M = \max|f^{(n+1)}|. \tag{2.11}$$

جدول الرموز

الرمز	الاسم	المعنى
R_n	البقايا	الخطأ بعد قطع الدرجة n
ξ	نقطة وسيطة	موجودة نظرياً في لاغرانج
M	أقصى مشتقّة	يضبط الحدّ الأعلى للخطأ

رسم توضيحي

<figure> الشكل<figcaption> 2.11: الخطأ $R_n(x)$ هو المساحة بين f و P_n. لاغرانج يضمن وجود ξ يجعل



شكل ٢.٠١١: *
البقايا كالمنطقة بين f و P_n

$|R_n| \le M|x-a|^{n+1}/(n+1)!$ — أيّ أنّ البقايا محصورة بأقصى انحناء.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اعتبار ξ معروفة	هي نظرية الوجود فقط	نستخدمها للحدّ الأعلى لا القيمة
نسيان M يعتمد على n	أعلى مشتقّة بتغيّر	خذ أقصى $\lvert f^{(n+1)}\rvert$ على الفترة
خلط Peano مع قيمة عددية	$o(\cdot)$ غير كمّي	استخدم لاغرانج للتقدير العملي
تجاهل أنّ $(x-a)^{n+1}$ قد يكبر	بعيداً عن a يكبر الخطأ	التقارب محلّي

أمثلة محلولة على صيغ البقايا (15 مثالاً)

مثال (11.3-1).

- **المعطيات:** e^x حول 0، تقدير لـ $R_2(x)$.
- **المطلوب:** حدّ أعلى للخطأ عند $x=1$.
- **الحل:**

١. $M = \max e^{\xi} = e^1 = e$ على $[0,1]$.

٢. $|R_2| \le e \cdot 1^3/6 \approx 0.453$. ■

- **النتيجة:** ≤ 0.453 (الحقيقي $e - 2.5 \approx 0.218$).
- **الربط بالذكاء الاصطناعي:** «حدّ أعلى لخطأ التقريب» — يضمن أمان تقدير exp المقطوع.

مثال (11.3-2).

- **المعطيات:** $\sin x$، P_3 عند $x=0.5$.
- **المطلوب:** حدّ لاغرانج.
- **الحل:**

١. $f^{(4)}(\xi) = -\sin\xi$، $|M| \le 1$.

٢. $|R_3| \le |0.5|^4/24 \approx 0.0026$. ■

- **النتيجة:** ≤ 0.0026.
- **الربط بالذكاء الاصطناعي:** «خطأ تقريب زاوية صغيرة» محدود — يبرّر إهمال الحدود العليا في الاستشعار.

مثال (11.3-3).

- **المعطيات:** $e^{0.1}$ بدرجة 1.
- **المطلوب:** خطأ لاغرانج.

- **الحل:**

١. $R_1 \le e^{0.1}(0.1)^2/2 \approx 1.105 \cdot 0.005 = 0.0055$. ■

- **النتيجة:** ≤ 0.0055.

- **الربط بالذكاء الاصطناعي:** «دقّة التقريب الخطّي» تحدّد خطوة التعلّم الآمنة محليّاً.

مثال (11.3-4).

- **المعطيات:** تقريب e^1 بخطأ $< 10^{-6}$.

- **المطلوب:** أصغر n؟

- **الحل:**

١. $|R_n| \le e/(n+1)! < 10^{-6}$.

٢. لـ $n = 9$: $e/10! \approx 2.718/3.6 \times 10^6 \approx 7.5 \times 10^{-7} < 10^{-6}$. ■

- **النتيجة:** $n = 9$.

- **الربط بالذكاء الاصطناعي:** «عدد الحدود لدقّة مطلوبة» — يشبه اختيار عرض النطاق الترددي لاكتساب النموذج.

مثال (11.3-5).

- **المعطيات:** e^x، الصيغة التكاملية لـ R_n.

- **المطلوب:** أثبت أنّها تؤول لـ e^x.

- **الحل:**

١. $R_n = \int_0^x e^t (x-t)^n/n!\, dt \le e^x x^{n+1}/(n+1)! \to 0$. ■

- **النتيجة:** التقارب مضمون.

- **الربط بالذكاء الاصطناعي:** «صيغة التكامل» تظهر في اشتقاق ELBO التكراري (المتبقّى يصغر).

مثال (11.3-6).

- **المعطيات:** f قابلة للاشتقاق n مرّة عند a.

- **المطلوب:** صيغة بيانو $R_n = o((x-a)^n)$.

- **الحل:**

١. من لاغرانج $R_n/|x-a|^n \to 0$؛ بيانو يصف السرعة فقط. ■

- **النتيجة:** o لا قيمة.

- **الربط بالذكاء الاصطناعي:** «تحليل الأخطاء اللانهائي الصغر» في براهين التقارب الطوبولوجي.

مثال (11.3-7).

- **المعطيات:** $\cos x$، P_2 عند $x = 0.3$.
- **المطلوب:** حدّ لاغرانج.
- **الحل:**

١. $f^{(3)}(\xi) = -\sin\xi$، $|M| \le 0.3$ (على $[0, 0.3]$) أو بأمان 1.

٢. $|R_2| \le 1 \cdot (0.3)^3/6 \approx 0.0045$. ■

- **النتيجة:** ≤ 0.0045.
- **الربط بالذكاء الاصطناعي:** «تقدير تحفّظي» — نأخذ $M = 1$ دائماً لضمان الحدّ الأعلى.

مثال (11.3-8).

- **المعطيات:** سلسلة متناوبة ترضي شرط ليبنتس.
- **المطلوب:** اربط بقايا لاغرانج.
- **الحل:**

١. الخطأ $\le$ أول حدّ مهمَل = صورة خاصّة من لاغرانج لـ $f^{(n+1)}$ متناوبة. ■

- **النتيجة:** متراجحة ليبنتس = لاغرانج.
- **الربط بالذكاء الاصطناعي:** «حدّ خطأ متناوب» يُستخدم في تقريب سريع بلا تقييم كلّ الحدود.

مثال (11.3-9).

- **المعطيات:** $\arctan x$ عند $x = 1$ بـ P_3.
- **المطلوب:** حدّ بقايا.
- **الحل:**

١. $f^{(4)}(x) = -6x(1+x^2)^{-3}$؛ $|M| \le 6$ على $[0, 1]$.

٢. $|R_3| \le 6/24 = 0.25$. ■

- **النتيجة:** ≤ 0.25 (فجوة بسبب بطء تقارب $\arctan$ عند 1).
- **الربط بالذكاء الاصطناعي:** «بطء التقارب عند الحافة» — يذكّر بنصف القطر المحدود.

مثال (10-3.11).

- **المعطيات:** $\ln(1+x)$، الصيغة التكاملية.
- **المطلوب:** عبّر R_n تكاملياً.
- **الحل:**

١. $R_n = \int_0^x \frac{(-1)^n n!}{(1+t)^{n+1}} \frac{(x-t)^n}{n!} dt = \int_0^x \frac{(-1)^n (x-t)^n}{(1+t)^{n+1}} dt$. ■

- **النتيجة:** صيغة تكاملية مغلقة.
- **الربط بالذكاء الاصطناعي:** «صيغة التكامل» تظهر في اشتقاق تقديرات بايز التحليلية.

مثال (11-3.11).

- **المعطيات:** قطع عند n $\Longrightarrow$ خطأ $O(|x-a|^{n+1})$.
- **المطلوب:** اربط بالترتيب.
- **الحل:**

١. من (2.11): $|R_n| \le M|x-a|^{n+1}/(n+1)! \Longrightarrow$ رتبة $n+1$. ■

- **النتيجة:** رتبة الخطأ $= n+1$.
- **الربط بالذكاء الاصطناعي:** «رتبة الخطأ» تقابل دقّة المقدّر حسب عدد الحدود.

مثال (12-3.11).

- **المعطيات:** $(1+x)^{\alpha}$ عند $x = 0.2$.
- **المطلوب:** حدّ البقايا لـ P_2.
- **الحل:**

١. $f^{(3)}(\xi) = \alpha(\alpha-1)(\alpha-2)(1+\xi)^{\alpha-3}$؛ لـ $\alpha = 1/2$، $|M| \le \frac{3}{4}(1)^{-2.5} = 0.375$.

٢. $|R_2| \le 0.375(0.2)^3/6 \approx 0.0005$. ■

- **النتيجة:** $\le 5 \times 10^{-4}$.
- **الربط بالذكاء الاصطناعي:** «خطأ تقريب الجذر» صغير قرب الصفر — موثوق لتطبيع الأوزان.

مثال (13-3.11).

- **المعطيات:** برهان (مخطّط) أنّ e غير نسبي عبر البقايا.
- **المطلوب:** اشرح الفكرة.
- **الحل:**

١. لو $e=p/q$، $q!\,e=q!\sum_{k=0}^{\infty}1/k!$؛ الجزء الذيل $q!\int_0^1 e^t(1-t)^q/q!dt$ يقع بين 0 و1 غير صحيح $\Longrightarrow$ تناقض. ■

- **نتيجة:** فكرة الاعتماد على ضبط البقايا.
- **الربط بالذكاء الاصطناعي:** «ضبط الخطأ لإثبات استحالة» — نمط يظهر في حدود قدرة التعلّم (PAC).

مثال (14-3.11).

- **المعطيات:** $f'(a)=0$ (نقطة حرجة).
- **المطلوب:** ماذا عن R_1؟
- **الحل:**

١. $P_1=f(a)$، $R_1=f(a+h)-f(a)=\frac{1}{2}f''(\xi)h^2$. ■

- **النتيجة:** الخطأ من الرتبة الثانية فوراً.
- **الربط بالذكاء الاصطناعي:** «عند النقطة الحرجة التقريب الخطّي ثابت» — أساس تحليل الحوض حول المُثلّث.

مثال (15-3.11).

- **المعطيات:** وجود ξ في لاغرانج لا قيمته.
- **المطلوب:** بيّن أنّنا نقدّر لا نحسب.
- **الحل:**

١. ξ وسيطة مضمونة لكنها تختلف بـ x ولا تُعبَّر صراحةً عادةً. ■

- **النتيجة:** نستخدمها للحدّ الأعلى.
- **الربط بالذكاء الاصطناعي:** «ضمان وجود بلا حساب» — مثل وجود الحلّ الأمثل في التعلّم المحدّب.

التعريف

dir="ltr"> <div
with ,**x** near C^2 class of $f : \mathbb{R}^d \to \mathbb{R}$ For **Taylor). (Multivariate 1.4.11 Definition**
:**h** increment

$$f(\mathbf{x}+\mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \tfrac{1}{2}\mathbf{h}^\top \nabla^2 f(\mathbf{x})\,\mathbf{h} + R_2. \tag{3.11}$$

dir="ltr"> <div
. $R_2 = o(\|\mathbf{h}\|^2)$ satisfies remainder The Hessian. the $\nabla^2 f$ and gradient the is ∇f Here

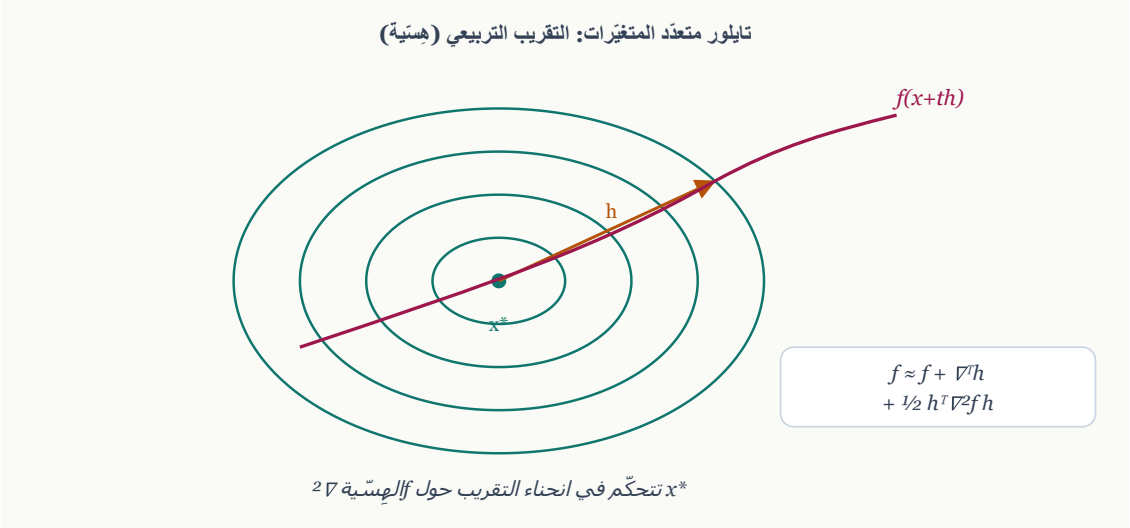
النظرية 1.4.11 (اتجاه الانحناء): الانحناء على طول **v** هو $\mathbf{v}^\top \nabla^2 f\,\mathbf{v}$؛ قيمه الذاتية تحدّد التقوّس (موجب=وعرة، سالب=سرج).

جدول الرموز

الرمز	الاسم	المعنى
∇f	التدرّج	متجه الدرجة الأولى
$\nabla^2 f$	الهِسّية	مصفوفة الدرجة الثانية
$\mathbf{h}$	الخَطوة	متجه الإزاحة

رسم توضيحي

<figure> الشكل<figcaption> 3.11: حول x^*، الدالة تُقرَّب بوعاء بيضاوي (متساويات الهِسّية). الخطّ الأحمر h



شكل ٣.١١: *
التقريب التربيعي وحوض الهِسّية

يقطع قطاعاً تربيعياً، انحناؤه = $h^\top \nabla^2 f\, h$.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
نسيان $\frac{1}{2}$ في الحدّ التربيعي	معامل هِسّية	اكتب $\frac{1}{2}h^\top Hh$
اعتبار الهِسّية دائماً موجبة	قد تكون سرجية	فحص القيم الذاتية
خلط ∇^2 مع $\nabla\nabla^\top$	الأولى هِسّية	$H_{ij} = \partial^2 f/\partial x_i \partial x_j$
إهمال بقايا الترتيب الثاني	الخطأ $o(\|h\|^2)$	لا تهمل إلا محلياً صغيراً

أمثلة محلولة على تايلور متعدّد المتغيّرات (15 مثالاً)

مثال (11.4-1).

- **المعطيات:** $f(x) = \frac{1}{2}x^\top Ax + b^\top x$ (تربيعي).
- **المطلوب:** أثبت تطابق تايلور من الدرجة 2 مع f.
- **الحل:**

١. $\nabla f = Ax + b$، $\nabla^2 f = A$.

٢. $f(x+h) = f + \nabla^\top h + \frac{1}{2}h^\top Ah = f$ تماماً (لا بقايا). ■

- **النتيجة:** متطابق.
- **الربط بالذكاء الاصطناعي:** «الخسائر التربيعية = تايلور تامّ» — أساس least squares و Newton.

مثال (11.4-2).

- **المعطيات:** $f(x,y) = x^2 + y^2$ عند $(0,0)$.
- **المطلوب:** الهِسّية.
- **الحل:**

١. $\nabla = (2x, 2y)$؛ $H = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$. ■

- **النتيجة:** $2I$ موجبة — حوض كروي.
- **الربط بالذكاء الاصطناعي:** «هِسّية موجبة ثابتة» = تقوّس متّسق — حالة مثالية لنيوتن.

مثال (11.4-3).

- **المعطيات:** عند نقطة حرجة $\nabla f = 0$، اقترب تربيعياً.
- **المطلوب:** اشتقّ اتجاه نيوتن.

- **الحل:**

١. $f(x+h) \approx f + \frac{1}{2}h^\top Hh$؛ نُصغّر: $\nabla(\frac{1}{2}h^\top Hh) = Hh = 0$.

٢. حلّ $Hh = -\nabla \implies h = -H^{-1}\nabla$. ■

- **النتيجة:** خطوة نيوتن.

- **الربط بالذكاء الاصطناعي:** «اتجاه نيوتن» = حلّ نظام خطّي بالهِسّية — أساس التحسين من الدرجة الثانية.

مثال (4-4.11).

- **المعطيات:** $f(x,y) = x^2 - y^2$ عند $(0,0)$.

- **المطلوب:** ماذا تدلّ الهِسّية؟

- **الحل:**

١. $H = \mathrm{diag}(2,-2)$ — قيم ذاتية متباينة الإشارة $\implies$ نقطة سرجية. ■

- **النتيجة:** سرج (saddle).

- **الربط بالذكاء الاصطناعي:** «نقاط السرج» تسيطر على فضاءات الشبكات العميقة (هضاب مسطّحة + سروج).

مثال (5-4.11).

- **المعطيات:** $f(x) = -\frac{1}{2}x^\top \Sigma^{-1} x$ (أسّ سلبي لتوزيع).

- **المطلوب:** التقريب التربيعي.

- **الحل:**

١. $\nabla = -\Sigma^{-1}x$، $\nabla^2 = -\Sigma^{-1}$؛ التقريب مطابق للأسّ. ■

- **النتيجة:** غاوسي = تربيعي تامّ.

- **الربط بالذكاء الاصطناعي:** «تقارب غاوسي بتايلور» = أساس approximation Laplace في بايز.

مثال (6-4.11).

- **المعطيات:** بقايا المربعات الصغرى $R(\beta) = \|y - X\beta\|^2$.

- **المطلوب:** الهِسّية.

- **الحل:**

١. $\nabla = -2X^\top(y - X\beta)$؛ $H = 2X^\top X$ (ثابتة موجبة شبه-معرّفة). ■

- **النتيجة:** هِسّية ثابتة.

- **الربط بالذكاء الاصطناعي:** «هِسّية constant» $\implies$ نيوتن يحلّ بخطوة واحدة — خاصّية least squares.

مثال (11.4-7).

- **المعطيات:** خسارة لوجستيك $\ell(\beta) = \sum \log(1 + e^{-y_i x_i^\top \beta})$.
- **المطلوب:** الهِسّية قرب المُثلّث.
- **الحل:**

١. $H = X^\top D X$، $D = \mathrm{diag}(p_i(1-p_i))$ موجبة المعرّفة. ■

- **النتيجة:** موجبة — محليّاً محدّب.
- **الربط بالذكاء الاصطناعي:** «هِسّية لوجستيك موجبة» تضمن تقارب نيوتن-لوجستيك.

مثال (11.4-8).

- **المعطيات:** انحناء على طول اتجاه الوحدة v.
- **المطلوب:** أثبت $= v^\top H v$.
- **الحل:**

١. $f(x+tv) = f + t\nabla^\top v + \frac{1}{2}t^2 v^\top H v + \cdots$؛ المشتقّة الثانية عند 0 هي $v^\top H v$. ■

- **النتيجة:** الانحناء الاتّجاهي.
- **الربط بالذكاء الاصطناعي:** «انحناء الاتجاه» يحدّد أين تتسطّح الخسارة — تحليل حادّة النموذج.

مثال (11.4-9).

- **المعطيات:** لابلاسيان $\Delta f = \sum \partial^2 f / \partial x_i^2$.
- **المطلوب:** اربطه بتايلور.
- **الحل:**

١. من تايلور: $f(x+he_i) + f(x-he_i) - 2f(x) = h^2 \partial^2 f/\partial x_i^2 + o(h^2)$؛ جمع الأبعاد $= h^2 \Delta f$. ■

- **النتيجة:** لابلاسيان = مجموع الانحناءات.
- **الربط بالذكاء الاصطناعي:** «اللابلاسيان المنفصل» = التفاف شبكي (CNN) — أساس الترشيح.

مثال (11.4-10).

- **المعطيات:** $f(x,y)=xy$ عند $(0,0)$.
- **المطلوب:** الحدّ التربيعي.
- **الحل:**

١. $\nabla=(y,x)=0$؛ $H=\begin{bmatrix}0&1\\1&0\end{bmatrix}$؛ الحدّ $=xy$ (مطابق). ■

- **النتيجة:** سرج بلا حدّ خطّي.
- **الربط بالذكاء الاصطناعي:** «حدود التفاعل xy» تظهر في ميزات المنتج والاهتمام.

مثال (11-4.11).

- **المعطيات:** عند نقطة حرجة، $f(x+h)=f+\frac{1}{2}h^{\top}Hh+o(\|h\|^2)$.
- **المطلوب:** صنّف حسب H.
- **الحل:**

١. موجبة $\Rightarrow$ أدنى محليّ؛ سالبة $\Rightarrow$ أعلى؛ متباينة $\Rightarrow$ سرج. ■

- **النتيجة:** تصنيف نيوتن-رافسون.
- **الربط بالذكاء الاصطناعي:** «تصنيف النقطة الحرجة» = فهم مشهد التحسين (loss landscape).

مثال (12-4.11).

- **المعطيات:** لوغاريتم softmax $g_i=\log\sum_j e^{z_j}$ عند z.
- **المطلوب:** التدرّج والهِسّية.
- **الحل:**

١. $\nabla g=p$؛ $H=\operatorname{diag}(p)-pp^{\top}$ (softmax) (موجبة شبه-معرّفة). ■

- **النتيجة:** هِسّية softmax معروفة.
- **الربط بالذكاء الاصطناعي:** «هِسّية softmax» تُستخدم في التحسين والتحليل التباينيّ للاحتمالات.

مثال (13-4.11).

- **المعطيات:** قيم ذاتية لـ H عند نقطة.

- **المطلوب:** ماذا تدلّ؟
- **الحل:**

١. هي انحناءات رئيسية (principal curvatures)؛ أصغرها يقارب أخطر اتجاه لتسطّح. ■

- **النتيجة:** «شكل الوعاء».
- **الربط بالذكاء الاصطناعي:** «القيم الذاتية للهِسّية» تقيس حادّة/تسطّح النموذج — مؤشّر التعميم.

مثال (11.4-14).

- **المعطيات:** خطوة نيوتن مقابل التدرّج.
- **المطلوب:** قارن.
- **الحل:**

١. تدرّج: $h = -\eta \nabla$ (لا يعرف الانحناء). نيوتن: $h = -H^{-1}\nabla$ (يضبط حسب الانحناء). ■

- **النتيجة:** نيوتن أسرع محليّاً.
- **الربط بالذكاء الاصطناعي:** «تكييف الخطوة بالهِسّية» = جوهر محسّنات/Adam الجيل الثاني.

مثال (11.4-15).

- **المعطيات:** $f(x_1, x_2) = x_1^2 + 2x_1x_2 + 3x_2^2$ عند $(0, 0)$.
- **المطلوب:** الحدّ التربيعي الكامل.
- **الحل:**

١. $H = \begin{bmatrix} 2 & 2 \\ 2 & 6 \end{bmatrix}$ موجبة المعرّفة؛ $f = \frac{1}{2}h^\top Hh$ بالضبط. ■

- **النتيجة:** تربيعي مطابق.
- **الربط بالذكاء الاصطناعي:** «صيغ تربيعية بحدود تفاعل» — نموذج كلّ شبكة خطّية/تربيعية.

التعريف

dir="ltr"> <div
-th$n$ the after series Taylor a Cutting **order). & error (Truncation 1.5.11 Definition**
satisfies error its fi p **order** is method A .R_n error truncation leaves term

$$|E| \le C\,|x-a|^{n+1} \quad \text{generally more or} \quad E = O(h^{p+1}). \tag{4.11}$$

dir="ltr"> <div
the fi **convergent** and ,h $\to$ 0 as holds bound the fi **asymptotic** is error say We
value. true the to tends itsefl approximation

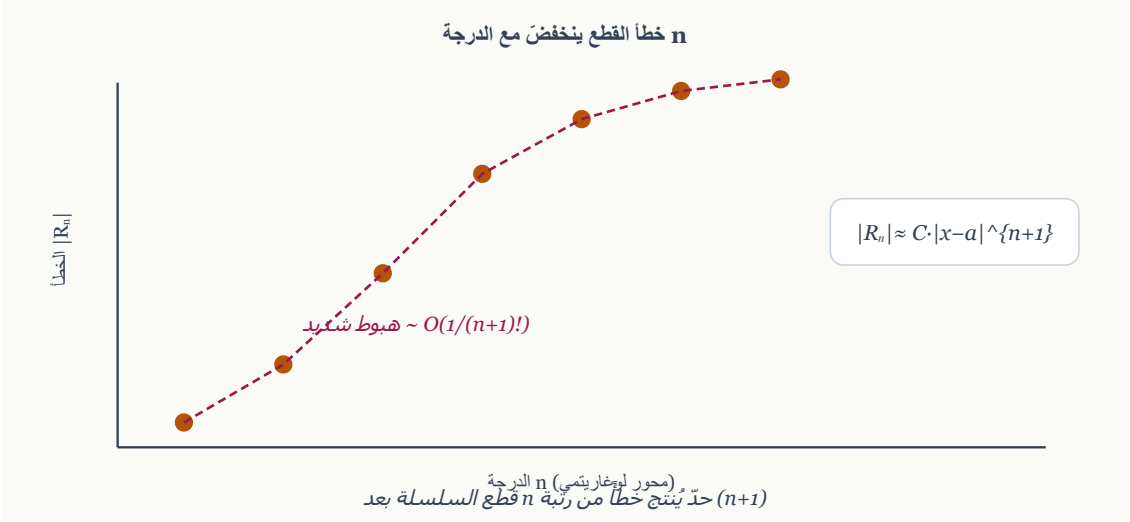
النظرية 1.5.11 (ترتيب الفروق): الفرق الأمامي $O(h)$، المركزي $O(h^2)$، وصيغ أكثر تماثلاً ترفع الرتبة.

جدول الرموز

الرمز	الاسم	المعنى
R_n	خطأ القطع	ما حُذف من السلسلة
p	الرتبة	قوة h في الخطأ
$O(\cdot)$	ترتيب كبير	سلوك حدّي

رسم توضيحي

<figure> الشكل<figcaption> 4.11: على محور لوغاريتمي، خطأ القطع $|R_n|$ يهبط بسرعة مع الدرجة n (تقريباً كـ



شكل ٤.٠١١: *
انخفاض خطأ القطع مع الدرجة

$1/(n+1)!$. قطع أبكر = رتبة أقلّ = خطأ أكبر.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«رتبة أعلى دائماً أفضل» خلط $O(h^p)$ مع $O(h^{p+1})$	تكلفة حسابية تزداد تعريف الرتبة	توازن دقّة/تكلفة الخطأ $O(h^{p+1})$ للدرجة p
نسيان أنّ O وصفي لا قيمي	لا يعطي الثابت C	قيّم C عملياً
اعتبار التقارب اللانهائي قريباً	قد يبطئ جداً	فحص رتبة النقصان

أمثلة محلولة على خطأ القطع والتقارب (15 مثالاً)

مثال (11.5-1).

- **المعطيات:** الفرق الأمامي $f'(x) \approx \frac{f(x+h)-f(x)}{h}$.
- **المطلوب:** رتبة الخطأ.
- **الحل:**

١. $f(x+h) = f + hf' + \frac{h^2}{2}f'' + \cdots \implies$ الخطأ $= \frac{h}{2}f'' + O(h^2) = O(h)$. ■

- **النتيجة:** رتبة 1.
- **الربط بالذكاء الاصطناعي:** «تقريب المشتقّة بالفرق» = نواة SGD التقريبي (ch08).

مثال (11.5-2).

- **المعطيات:** الفرق المركزي $\frac{f(x+h)-f(x-h)}{2h}$.
- **المطلوب:** رتبة الخطأ.
- **الحل:**

١. الحدود الفردية تلغي؛ الخطأ $= -\frac{h^2}{6}f''' + \cdots = O(h^2)$. ■

- **النتيجة:** رتبة 2.
- **الربط بالذكاء الاصطناعي:** «الفرق المركزي أدقّ» — يُفضّل في المشتقّات العددية للخسائر.

مثال (11.5-3).

- **المعطيات:** اشتقاق مشتقّة عددية (tie) مع الفصل 8).
- **المطلوب:** اربط الفرق بـ تايلور.
- **الحل:**

١. كلّ صيغة فرق = قطع تايلور لمتعدّدة تلغي حدوداً. ■

- **النتيجة:** الفروق = تايلور مقصوص.
- **الربط بالذكاء الاصطناعي:** autodffi» أدقّ من الفرق» لأنه يتجنّب خطأ القطع هذا.

مثال (5.11-4).

- **المعطيات:** e^x مقطوعة عند n حدّ لـ $x = 1$.
- **المطلوب:** حدّ الخطأ.
- **الحل:**

١. $|R_n| \le e/(n+1)!$. لـ $n = 5$: $e/720 \approx 0.0038$. ■

- **النتيجة:** ≤ 0.0038.
- **الربط بالذكاء الاصطناعي:** «عدد الحدود لدقّة» — يشبه عرض النطاق لاكتساب النموذج.

مثال (5.11-5).

- **المعطيات:** نريد خطأ $< 10^{-4}$ لـ e^1.
- **المطلوب:** أوجد n من (11.4).
- **الحل:**

١. $e/(n+1)! < 10^{-4} \Longrightarrow (n+1)! > 27180 \Longrightarrow n+1 \ge 8 \Longrightarrow n = 7$. ■

- **النتيجة:** $n = 7$.
- **الربط بالذكاء الاصطناعي:** «تسوية الدقّة بالترتيب» — مقايضة دقّة/حساب كلاسيكية.

مثال (5.11-6).

- **المعطيات:** $O(h^2)$ مقابل تقارب فعلي.
- **المطلوب:** ميز بينهما.
- **الحل:**

١. $O(h^2)$ يصف السلوك الحدّي؛ التقارب الفعلي يحتاج $h \to 0$ والثابت C معقول. ■

- **النتيجة:** وصفي vs وجودي.
- **الربط بالذكاء الاصطناعي:** «نظرية تقارب vs ممارسة» — SGD له حدّ $O(1/\sqrt{T})$ لكن الثابت يهمّ.

مثال (5.11-7).

- **المعطيات:** خطأ SGD بعد T خطوة $= O(1/\sqrt{T})$.

- **المطلوب:** اربطه بـ (4.11).
- **الحل:**

١. $h = 1/\sqrt{T} \Longrightarrow$ الخطأ $O(h)$ من رتبة أولى — تقارب بطيء لكن مضمون. ■

- **النتيجة:** رتبة نقصان $1/2$.
- **الربط بالذكاء الاصطناعي:** «لماذا نحتاج آلاف الخطوات» — تحليل عيّنات التحسين العشوائي.

مثال (11.5-8).

- **المعطيات:** خطأ Carlo Monte $= O(1/\sqrt{N})$.
- **المطلوب:** اشرح.
- **الحل:**

١. التباين $\sigma^2/N \Longrightarrow$ الانحراف المعياري $\propto 1/\sqrt{N}$. ■

- **النتيجة:** نقصان جذري.
- **الربط بالذكاء الاصطناعي:** «كم عيّنة نحتاج؟» — أساس حجم الدُفعة (batch) والتقدير التجريبي.

مثال (11.5-9).

- **المعطيات:** استقراء ريتشاردسون (Richardson) من صيغتين بترتيب h^p.
- **المطلوب:** كيف يرفع الرتبة؟
- **الحل:**

١. $A(h) = A + ch^p + \ldots$، $A(2h) = A + c2^p h^p + \ldots \Longrightarrow$ دمجهما يلغي $h^p \Longrightarrow$ رتبة $2p$. ■

- **النتيجة:** مضاعفة الرتبة.
- **الربط بالذكاء الاصطناعي:** «تجميع تقديرات» لرفع الدقّة — مثل ensemble. models

مثال (11.5-10).

- **المعطيات:** طريقة أويلر $y_{n+1} = y_n + hf$ محلياً.
- **المطلوب:** رتبة الخطأ المحلّي.
- **الحل:**

١. من تايلور الحلّ: الخطأ المحلي $O(h^2)$ (عالمياً $O(h)$). ■

- **النتيجة:** محليّ رتبة 2.
- **الربط بالذكاء الاصطناعي:** «خطوة تكامل «ODE = أساس حلّ معادلات الانتشار (dffiusion SDE).

مثال (11-5.11).

- **المعطيات:** شبكة فرق (stencil) من 5 نقاط.
- **المطلوب:** رتبتها.
- **الحل:**

١. تلغي حدوداً حتى $h^4 \implies$ خطأ $O(h^4)$ للمشتقّة الثانية. ■

- **النتيجة:** رتبة 4.
- **الربط بالذكاء الاصطناعي:** «نواة التفاف أوسع = دقّة أعلى» — مقايضة في CNN.

مثال (12-5.11).

- **المعطيات:** قاعدة شبه المنحرف للتكامل.
- **المطلوب:** رتبة الخطأ.
- **الحل:**

١. من تايلور: الخطأ الكلّي $O(h^2)$ (للدالة ناعمة). ■

- **النتيجة:** رتبة 2.
- **الربط بالذكاء الاصطناعي:** «تقريب التوقّع بجمع» — كلّ تقدير متوسّط هو تكامل مقطوع.

مثال (13-5.11).

- **المعطيات:** تقريب الانتباه بمرتبة منخفضة (low-rank).
- **المطلوب:** اربطه بخطأ القطع.
- **الحل:**

١. اقتطاع قيم مفردات = قطع توسّع طيفي؛ الخطأ $\propto$ مجموع القيم المهملة. ■

- **النتيجة:** خطأ اقتطاع طيفي.
- **الربط بالذكاء الاصطناعي:** «تقليص الانتباه» (Linformer) = تقليل ترتيب التقريب لخفض التعقيد.

مثال (14-5.11).

- **المعطيات:** نموذج انحدار تلقائي (AR) بترتيب p.
- **المطلوب:** ما علاقة الترتيب بالخطأ؟
- **الحل:**

١. قطع التاريخ عند p يُهمل ذاكرة أقدم؛ الخطأ يخفضّ مع p ثمّ يشبع. ■

- **النتيجة:** رتبة محدودة.
- **الربط بالذكاء الاصطناعي:** «طول السياق» = رتبة التقريب — مقايضة ذاكرة/دقّة.

مثال (15-5.11).

- **المعطيات:** تعريف «رتبة p».
- **المطلوب:** صغه بدقّة.
- **الحل:**

١. $E = O(h^{p+1})$ يعني $|E| \le C|h|^{p+1}$ لـ h صغير. ■

- **النتيجة:** رتبة p $\Longrightarrow$ خطأ $(p+1)$.
- **الربط بالذكاء الاصطناعي:** «فهم الرتبة» ضروري لتحليل كلّ خوارزمية تقريب في ML.

التعريف

dir="ltr"> <div
,δx within known is x If **number)، condition & propagation (Error 1.6.11 Definition**
dffierentiable: f for then

$$\delta f \approx |f'(x)|\,\delta x.$$

is x at f of **number condition** (relative) The

$$\kappa(x) = \left|\frac{x\,f'(x)}{f(x)}\right|, \qquad \frac{|\delta f|}{|f|} \le \kappa(x)\,\frac{|\delta x|}{|x|}. \tag{5.11}$$

dir="ltr"> <div
.$\delta f \le \|\mathbf{J}_f\|\,\|\delta\mathbf{x}\|$ variables, several In

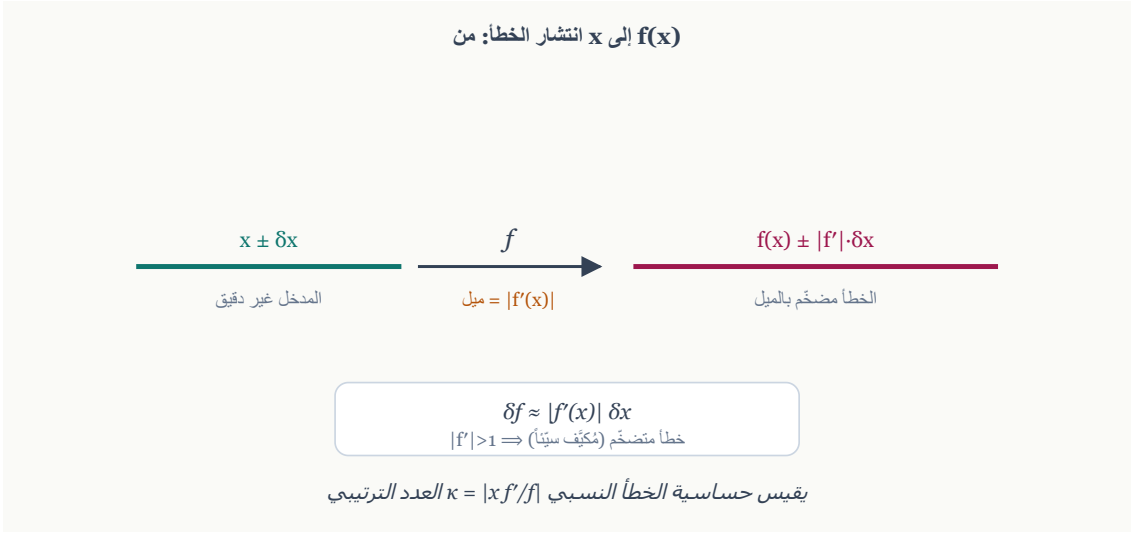
النظرية 1.6.11 (التكيّف السيّئ): $1 \quad \gg \quad \kappa$ يعني تضخّماً هائلاً للخطأ النسبي — مشكلة مُكيَّفة سيّئاً (ill-conditioned)، وترتبط بقيم مفردات كبيرة للهِسّية/المصفوفة.

جدول الرموز

الرمز	الاسم	المعنى
δf	خطأ المخرج	ينتج عن δx
κ	عدد التكيّف	مضخّم الخطأ النسبي
$\|\|J\|\|$	نُرم اليعقوبية	حدّ انتشار الخطأ المتجهي

رسم توضيحي

<figure> الشكل<figcaption>5.11: خطأ في المدخل $x \pm \delta x$ يمرّ عبر f فيصبح $f(x) \pm |f'(x)|\delta x$. إذا كان



شكل ٥.١١: *
انتشار الخطأ عبر f

$|f'| > 1$ (أو $\kappa \gg 1$) يتضخّم الخطأ — «تكيّف سيّئ».</figcaption></figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط الخطأ المطلق بالنسبي	تكيّف يقيس النسبي	استخدم $\delta f/\|f\|$
نسيان أنّ κ محلّي	يختلف بـ x	قيّم عند نقطة العمل
اعتبار f سلسة كافية	القفزات تكسر التحليل	افحص الاستمرارية
إهمال تراكم الطبقات	كلّ طبقة تضرب κ	$\kappa_{\text{net}} \approx \prod \kappa_i$

أمثلة محلولة على انتشار الخطأ والتكيّف (15 مثالاً)

مثال (1-6.11).

- **المعطيات:** $f(x, y) = x + y$، خطأ كلاهما δ.
- **المطلوب:** خطأ المجموع.
- **الحل:**

١. $|\partial_x| + |\partial_y|$ كلاهما 1 $\Longrightarrow \delta f \leq \delta + \delta = 2\delta$. $\delta f \approx$ ■

- **النتيجة:** مجموع الأخطاء المطلقة.
- **الربط بالذكاء الاصطناعي:** «تراكم خطأ الجمع» — يحدّ دقّة جمع الاحتمالات.

مثال (11.6-2).

- **المعطيات:** $f = xy$، خطأ نسبي $\varepsilon_x, \varepsilon_y$.
- **المطلوب:** خطأ نسبي للمُنتَج.
- **الحل:**

١. $\varepsilon_f \approx \varepsilon_x + \varepsilon_y \Longrightarrow \frac{\delta f}{|f|} \approx \frac{\delta x}{x} + \frac{\delta y}{y}$. ■

- **النتيجة:** تجميع نسبي.
- **الربط بالذكاء الاصطناعي:** «خطأ مُنتَج الطبقات» = مجموع أخطاء الأوزان — يفسّر تراكمها.

مثال (11.6-3).

- **المعطيات:** $f(x) = x^p$.
- **المطلوب:** $\kappa(x)$.
- **الحل:**

١. $f' = px^{p-1}$؛ $\kappa = |x \cdot px^{p-1}/x^p| = |p|$. ■

- **النتيجة:** $\kappa = |p|$ (مستقلّ عن x!).
- **الربط بالذكاء الاصطناعي:** «رفع القوة» له تكيّف $|p|$ — يفسّر حساسية ReLU^p والميزات التربيعية.

مثال (11.6-4).

- **المعطيات:** $f(x) = e^x$.
- **المطلوب:** التكيّف.
- **الحل:**

١. $\kappa = |xe^x/e^x| = |x|$. قرب الصفر مُكيَّف جيّداً، لـ x كبيرة سيّئ. ■

- **النتيجة:** $\kappa = |x|$.
- **الربط بالذكاء الاصطناعي:** exp» كبير مُكيَّف سيّئاً» — سبب log-sum-exp (ch06) لتفادي الانفجار.

مثال (11.6-5).

- **المعطيات:** $f(x) = 1 - \cos x$ لـ x صغير.
- **المطلوب:** لماذا خطير؟ (tie مع ch06)
- **الحل:**

١. $1 - \cos x \approx x^2/2 \implies$ طرح متقاربين = إلغاء كارثي. استخدم الصيغة المربّعة. ■

- **النتيجة:** تكيّف سيّئ محليّ.
- **الربط بالذكاء الاصطناعي:** «الإلغاء الكارثي» يظهر في خسارة المسافة والزوايا — تجنّبه بالصيغ المربّعة.

مثال (11.6-6).

- **المعطيات:** $f = x/y$.
- **المطلوب:** خطأ نسبي.
- **الحل:**

١. $\varepsilon_f \approx \varepsilon_x + \varepsilon_y$. ■

- **النتيجة:** تجميع كالمُنتَج.
- **الربط بالذكاء الاصطناعي:** «قسمة الاحتمالات» (مثل بايز) يجمع أخطاء البسط والمقام.

مثال (11.6-7).

- **المعطيات:** $f(x) = A^{-1}b$، خطأ في A.
- **المطلوب:** اربط بـ $\kappa(A)$ (tie مع ch05).
- **الحل:**

١. $\frac{\|\delta x\|}{\|x\|} \le \kappa(A)\frac{\|\delta A\|}{\|A\|}$، $\kappa = \|A\|\|A^{-1}\|$. ■

- **النتيجة:** تكيّف المصفوفة.
- **الربط بالذكاء الاصطناعي:** «انهيار عكس المصفوفة» — يفسّر عدم استقرار least squares سيّئ التكيّف.

مثال (11.6-8).

- **المعطيات:** شبكة بـ L طبقة، كل طبقة κ_i.
- **المطلوب:** تكيّف الشبكة.
- **الحل:**

١. $\kappa_{\text{net}} \approx \prod_{i=1}^{L} \kappa_i$ (تقريباً). ■

- **النتيجة:** تضخّم مضروب.
- **الربط بالذكاء الاصطناعي:** «لماذا الشبكات العميقة هشّة» — تراكم التكيّف عبر الطبقات.

مثال (11.6-9).

- **المعطيات:** قارن خطأً مطلقاً (10^{-3}) ونسبياً.
- **المطلوب:** متى النسبي أهمّ؟
- **الحل:**

١. إذا $|f| = 10^{-6}$ فخطأ 10^{-3} = نسبي 10^{3} (كارثي)؛ مطلقاً صغير. ■

- **النتيجة:** النسبي يصف الحجم.
- **الربط بالذكاء الاصطناعي:** «خطأ نسبي في الاحتمالات الصغيرة» — أساس تقييم الاحتمالات النادرة.

مثال (11.6-10).

- **المعطيات:** انتشار التباين $\text{Var}(f(X))$.
- **المطلوب:** قرّبه بتايلور من الدرجة الأولى.
- **الحل:**

١. $f(X) \approx f(\mu) + f'(\mu)(X-\mu) \Longrightarrow \text{Var} \approx [f'(\mu)]^2 \,\text{Var}(X)$. ■

- **النتيجة:** تباين منتشر خطّياً.
- **الربط بالذكاء الاصطناعي:** «انتشار عدم اليقين» (propagation) — أساس بايز التقريبي وقياس الثقة.

مثال (11.6-11).

- **المعطيات:** $f(x) = \log x$.
- **المطلوب:** هل اللوغاريتم يُثبّت؟

- **الحل:**

١. $\kappa = |x \cdot (1/x)/\log x| = |1/\log x|$، كبيرًا لـ $x \approx 1$ لكنه يضبط مقاييس واسعة. ■

- **النتيجة:** يضبط النطاقات.

- **الربط بالذكاء الاصطناعي:** «تحويل لوغاريتمي» يُثبّت التباين عبر المقاييس — شائع في المعالجة.

مثال (11.6-12).

- **المعطيات:** $f(x) = \text{softmax}(x)_i$.

- **المطلوب:** التكيّف حول قيم كبيرة.

- **الحل:**

١. المشتقّة $p_i(1-p_i) \leq 1/4 =$؛ مُكيَّف جيّداً محليّاً. ■

- **النتيجة:** مستقرّ.

- **الربط بالذكاء الاصطناعي:** softmax» مُكيَّف جيّداً» — سبب استقراره مقابل exp مباشر.

مثال (11.6-13).

- **المعطيات:** تدرّجات تتلاشى/تنفجر في شبكة عميقة.

- **المطلوب:** اربط بالتكيّف.

- **الحل:**

١. $\|\mathbf{J}_{\text{net}}\| \approx \prod \|W_i\|$؛ إن كانت $1 >$ تنفجر، $1 <$ تتلاشى. ■

- **النتيجة:** تكيّف مضروب = مشكلة التدرّج.

- **الربط بالذكاء الاصطناعي:** «انفجار/تلاشي التدرّج» — حلوله (Batchnorm, residual) تخفض التكيّف المضروب.

مثال (11.6-14).

- **المعطيات:** $f : \mathbb{R}^d \to \mathbb{R}^m$، δx صغير.

- **المطلوب:** حدّ الخطأ.

- **الحل:**

١. $\|\delta f\| \leq \|J_f\| \, \|\delta x\|$ (نُرم المصفوفة). ■

- **النتيجة:** اليعقوبية تضبط الانتشار.

- **الربط بالذكاء الاصطناعي:** «نُرم اليعقوبية = استقرار الشبكة» — يقاس في تحليل حساسية النموذج.

مثال (15-6.11).

- **المعطيات:** صيغة $\kappa = |xf'/f|$.
- **المطلوب:** طبّقها على $f(x) = x$ نفسها.
- **الحل:**

١. $\kappa = |x \cdot 1/x| = 1$ دائماً — الهوية مُكيَّفة تماماً. ■

- **النتيجة:** المرجع المعياري.
- **الربط بالذكاء الاصطناعي:** «المقارنة بـ $\kappa = 1$» تُقيّم جودة تكيّف أيّ دالة.

النظريات والصيغ

dir="ltr"> <div
is step Newton the ,f minimizing For **Gauss-Newton). & (Newton 1.7.11 Theorem**

$$\mathbf{x}_{k+1} = \mathbf{x}_k - H_f^{-1} \nabla f(\mathbf{x}_k).$$

Gauss-Newton the by approximated is Hessian the ,$\frac{1}{2}\|r(\mathbf{x})\|^2$ squares least nonlinear For
:$J_r^\top J_r$ matrix

$$\mathbf{x}_{k+1} = \mathbf{x}_k - (J_r^\top J_r)^{-1} J_r^\top r.$$

$$\text{Newton:} x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)} \quad (1\text{-D}); \qquad \text{GN:} J^\top J\,\delta = -J^\top r. \tag{6.11}$$

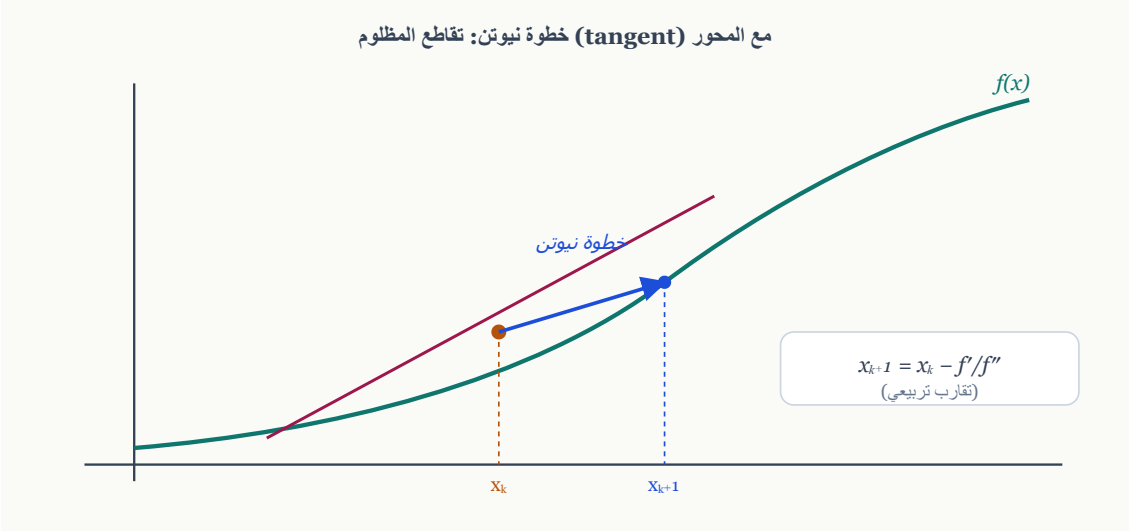
النظرية 1.7.11 (التفاضل الآلي): backprop يحسب ∇f و $\nabla^2 f$ (أو منتجاتها بأشعة) **بدقّة رياضية** — أيّه يُنتج معاملات تايلور دون خطأ قطع.

جدول الرموز

الرمز	الاسم	المعنى
H_f	هِسّية الهدف	انحناء دالة الخسارة
J_r	يعقوبية المتبقّي	مشتقّات الأخطاء
GN	غاوس-نيوتن	تقريب هِسّية بـ $J^\top J$

رسم توضيحي

<figure> الشكل<figcaption> 6.11: نيوتن يأخذ خطوة نحو جذر المظلوم (tangent) عند x_k؛ النتيجة x_{k+1}. عند تقارب جيّد يصل تربيعياً (أسرع من التدرّج).</figcaption>/ </figure>



شكل ٦٠١١: *
خطوة نيوتن على منحنى محدّب

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
استخدام نيوتن عند هِسّية غير موجبة	قد يصعد لا ينزل	أضف تنعيم Levenberg–Marquardt/
اعتبار GN = هِسّية حقيقية	هي تقريب	صالحة قرب المُثلّث فقط
نسيان تكلفة عكس H	$O(d^3)$	استخدم تقريبات (K-FAC/Shampoo)
الخلط بين تدرّج ونيوتن	سرعة تقارب مختلفة	تدرّج $O(1/k)$، نيوتن تربيعي

أمثلة محلولة على تطبيقات الذكاء الاصطناعي (15 مثالاً)

مثال (11.7-1).

- **المعطيات:** نيوتن على $f(x) = x^2 - 2$ لإيجاد $\sqrt{2}$.
- **المطلوب:** خطوة من $x_0 = 1$.
- **الحل:**

١. $f' = 2x,\ f'' = 2$؛ الكسر $x_1 = 1 - (2-2)/2 = 1$؟ $\Longrightarrow (x^2-2)/(2x) = (1-2)/2 = -0.5$
$x_1 = 1 - (-0.5) = 1.5$.

٢. $x_2 = 1.5 - (0.25/3) = 1.4167$. ■

- **النتيجة:** تقارب سريع نحو 1.4142.
- **الربط بالذكاء الاصطناعي:** «نيوتن تربيعي» — نموذج لسرعة التحسين من الدرجة الثانية.

مثال (11.7-2).

- **المعطيات:** خسارة لوجستيك أحادية $\ell(w)$.
- **المطلوب:** خطوة نيوتن.
- **الحل:**

١. $\ell' = p - y$، $\ell'' = p(1-p) > 0$؛ $w_{k+1} = w_k - (p-y)/(p(1-p))$. ■

- **النتيجة:** خطوة مضبوطة باليقين.
- **الربط بالذكاء الاصطناعي:** «نيوتن-لوجستيك» يتقارب في خطوات قليلة — أسرع من SGD.

مثال (11.7-3).

- **المعطيات:** مربعات صغرى غير خطّية $r_i(x)$.
- **المطلوب:** خطوة غاوس-نيوتن.
- **الحل:**

١. $J^\top J\,\delta = -J^\top r$؛ الحلّ δ ثمّ $x \leftarrow x + \delta$. ■

- **النتيجة:** تقارب محليّ سريع.
- **الربط بالذكاء الاصطناعي:** «Gauss-Newton» = أساس خوارزميات الملاءمة (curve fitting، bundle adjustment).

مثال (11.7-4).

- **المعطيات:** تحت أيّ شرط تقارب نيوتن تربيعياً؟
- **الحل:**

١. قرب جذر بـ f'' مستمرّة غير صفرية $\Rightarrow |e_{k+1}| \le C|e_k|^2$ (تربيعي). ■

- **النتيجة:** تقارب تربيعي محليّ.
- **الربط بالذكاء الاصطناعي:** «لماذا Adam لا يصل بسرعة نيوتن» — الفرق في الرتبة.

مثال (11.7-5).

- **المعطيات:** شبكة بـ backprop.
- **المطلوب:** كيف يحسب معاملات تايلور؟
- **الحل:**

١. قاعدة السلسلة (ch09) تحسب ∇ بدقّة؛ تفاضل من الدرجة الثانية (reverse-mode) يحسب منتجات Hv. ■

- **النتيجة:** تايلور بدون خطأ قطع.
- **الربط بالذكاء الاصطناعي:** autodiff» = تايلور دقيق» — يتفوّق على الفروق المنتهية (11.5-3).

مثال (11.7-6).

- **المعطيات:** التدرّج الطبيعي (Natural Gradient).
- **المطلوب:** اربطه بتايلور على فضاء Riemannian.
- **الحل:**

١. التقريب التربيعي يُقاس بـ مصفوفة المعلومات F؛ الخطوة $\tilde{\nabla} = F^{-1}\nabla$. ■

- **النتيجة:** نيوتن على فضاء المعاملات.
- **الربط بالذكاء الاصطناعي:** «Natural gradient» يُثبّت التكيّف عبر هندسة فيشر (الفصل 29 لاحقاً).

مثال (11.7-7).

- **المعطيات:** تحديث لانغفين $x_{k+1} = x_k - \eta \nabla U(x_k) + \sqrt{2\eta}\,\xi$.
- **المطلوب:** ما دور تايلور؟
- **الحل:**

١. ∇U هو الدرجة الأولى من تايلور لـ U؛ التحديث يسير نحو الحوض. ■

- **النتيجة:** مشي عشوائي موجّه بالتدرّج.
- **الربط بالذكاء الاصطناعي:** «Langevin MCMC» — أساس أخذ العيّنات من التوزيعات (وطالب dffiusion).

مثال (11.7-8).

- **المعطيات:** مطابقة السكور (Score matching).
- **المطلوب:** اربط بتايلور/المشتقّات.
- **الحل:**

١. السكور $\nabla_x \log p(x)$ هو الدرجة الأولى؛ المطابقة تُقرّب p عبر تطابق تباين السكور. ■

- **النتيجة:** تعلّم بلا عينات سلبية.
- **الربط بالذكاء الاصطناعي:** «Score-based models» — أساس dffiusion الحديث (مشتقّة لوغ-كثافة).

مثال (11.7-9).

- **المعطيات:** محسّنات من الدرجة الثانية (K-FAC, Shampoo).
- **المطلوب:** ماذا تقرّب؟
- **الحل:**

١. تقرّب H^{-1} بعوامل كرونيكرية/كتل لتفادي عكس $d \times d$ كامل. ■

- **نتيجة:** نيوتن عمليّ.
- **الربط بالذكاء الاصطناعي:** «نيوتن قابل للتطوير» — يقرّب الهِسّية بدل حسابها كاملة.

مثال (11.7-10).

- **المعطيات:** تدرّج السياسة (Policy Gradient).
- **المطلوب:** اربط بتايلور للمكافأة.
- **الحل:**

١. تغيير السياسة $\nabla_\theta J \approx \int \nabla_\theta \pi(a|s) Q \, d\tau$ = معامل تايلور الأول للعائد. ■

- **النتيجة:** تدرّج من الدرجة الأولى.
- **الربط بالذكاء الاصطناعي:** «PG = مشتقّة العائد» — كلّ RL يعتمد على تايلور من الدرجة الأولى.

مثال (11.7-11).

- **المعطيات:** نواة التماس العصبية (NTK).
- **المطلوب:** ما دور التقريب الخطّي؟
- **الحل:**

١. عند العرض اللانهائي، $f(\theta) \approx f(\theta_0) + J_{\theta_0}(\theta - \theta_0)$ — تايلور من الدرجة الأولى يُثبت تجمّد التدريب. ■

- **النتيجة:** خطّي حول التهيئة.
- **الربط بالذكاء الاصطناعي:** «NTK» (الفصل 40) يفسّر لماذا الشبكات العميقة تتعلّم كنواة — عبر تايلور.

مثال (11.7-12).

- **المعطيات:** مبرهنة Tweedie في dffiusion.
- **المطلوب:** اربط بتايلور.
- **الحل:**

١. $\mathbb{E}[x_0|x_t] = \frac{1}{\sigma_t^2}(x_t + \sigma_t^2 \nabla_{x_t} \log p_t(x_t))$ — السكور من الدرجة الأولى يصلح المتوسّط. ■

- **النتيجة:** إزالة الضجيج بتايلور.
- **الربط بالذكاء الاصطناعي:** «Tweedie» = «السكور» — قلب عينة dffiusion (الفصل 41).

مثال (11.7-13).

- **المعطيات:** Adam كمحسّن من الدرجة الأولى.
- **المطلوب:** لماذا ليس نيوتن؟
- **الحل:**

١. Adam يستخدم لحظات التدرّج (درجة أولى) فقط؛ لا هِسّية $\Longrightarrow$ أبطأ لكن أرخص بكثير. ■

- **النتيجة:** تريدو/آدم = تايلور درجة 1.
- **الربط بالذكاء الاصطناعي:** «العمليّة تغلب الكمال» — Adam هو المعيار رغم بطئه النظري.

مثال (11.7-14).

- **المعطيات:** حادّة النموذج (sharpness) عبر الهِسّية.
- **المطلوب:** كيف تُقاس؟
- **الحل:**

١. $\lambda_{\max}(\nabla^2 \ell)$ = أعلى انحناء؛ حادّة عالية $\perp$ تعميم ضعيف غالباً. ■

- **النتيجة:** مؤشّر تعميم.
- **الربط بالذكاء الاصطناعي:** «تسطيح المشهد» (Sharpness-Aware Minimization) يحسّن التعميم عبر الهِسّية.

مثال (11.7-15).

- **المعطيات:** تقريب غاوس-نيوتن $H \approx J^\top J$.
- **المطلوب:** متى يساوي الهِسّية الحقيقية؟
- **الحل:**

١. $H = J^\top J + \sum r_i \nabla^2 r_i$؛ إن كانت الأخطاء $r_i \approx 0$ (قرب المُثلّث) يتطابقان. ■

- **النتيجة:** GN صالح قرب الحلّ.
- **الربط بالذكاء الاصطناعي:** «لماذا GN مستقرّ» — لـ $J^\top J$ شبه موجبة دائماً (لا انعكاس مفسد).

خيط الفصل

١. **متعدّدات تايلور (2.11)** تحوّل أيّ دالة ناعمة إلى متعدّدة حدود محليّاً — أساس كلّ تقريب عددي.

٢. **البقايا (3.11)** تضبط «حجم الخطأ» بعد القطع — لاغرانج للحدّ الأعلى، التكاملية للبرهان، بيانو للسرعة.

٣. **تايلور المتعدّد (4.11)** يُدخل الهِسّية $\nabla^2 f$ — الانحناء الذي يفرق بين حوض وسرج.

٤. **خطأ القطع (5.11)** يمنحنا لغة «الرتبة» $O(h^{p+1})$ — توازن دقّة/تكلفة في كلّ خوارزمية.

٥. **انتشار الخطأ (6.11)** يحوّل الخطأ إلى «تكيّف» κ — يفسّر انفجار/تلاشي التدرّج.

٦. **التطبيقات (7.11)** تجمع الكلّ: نيوتن = تايلور درجة 2، autodiff = معاملات دقيقة، dffiusion/Tweedie = سكور من الدرجة الأولى.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
∇, ∇^2 من تايلور	التحسين (الفصل 20+)
بقايا وخطأ القطع	تحليل تقارب SGD/MCMC
تكيّف κ	الاستقرار العددي، العكس
Gauss-Newton	ملاءمة غير خطّية، adjustment bundle
السكور $\nabla \log p$	matching score dffiusion،
خطّي/NTK حول التهيئة	نظرية الشبكات العميقة (الفصل 40)

١. اكتب $P_4(x)$ لـ $f(x) = \cos x$ حول 0 وحدّد نصف القطر.

٢. أثبت $e^x = \sum x^k/k!$ عبر تايلور (حول 0) وحدّد التقارب.

٣. لـ $f(x) = \ln(1+x)$، أوجد $R_3(0.5)$ بصيغة لاغرانج.

٤. قرّب $\sqrt{1.05}$ بدرجة 2 وقدّر الخطأ بـ (2.11).

٥. عرّف $\kappa(x)$ وأثبت أنّ $f(x) = x^p$ لها $\kappa = |p|$ لـ $x > 0$.

٦. أثبت أنّ الفرق المركزي رتبته $O(h^2)$ عبر تايلور.

٧. لـ $f(x,y)=x^2-y^2$، احسب ∇ و ∇^2 وصنّف النقطة $(0,0)$.

٨. اشتقّ خطوة نيوتن $h=-H^{-1}\nabla$ من التقريب التربيعي.

٩. لـ $f(x)=e^x$ عند $x=10$، ما κ؟ ولماذا يُنصح بـ log-sum-exp؟

١٠. طبّق Gauss-Newton على $r(x)=[x-1,\ 2x-2]^\top$ من $x_0=0$.

١١. بيّن أنّ $f(x)=x_1^2+2x_1x_2+3x_2^2$ تربيعية تماماً (تايلور = الدالة).

١٢. حدّد رتبة خطأ قاعدة سيمبسون للتكامل.

١٣. باستقراء ريتشاردسون من صيغتين $O(h^2)$، ما الرتبة الناتجة؟

١٤. لـ $f(x)=A^{-1}b$، أثبت $\frac{\|\delta x\|}{\|x\|}\le\kappa(A)\frac{\|\delta A\|}{\|A\|}$.

١٥. اربط انفجار التدرّج بـ $\prod\|W_i\|$ واقترح حلاً (Batchnorm/Residual).

١٦. أثبت أنّ Δf يظهر كمجموع الانحناءات الاتجاهية (عبر تايلور).

١٧. لـ softmax، logit احسب ∇ و ∇^2 (كنتيجة 4.11-12).

١٨. بيّن أنّ GN موجبة شبه-معرّفة دائماً (لـ $J^\top J$).

١٩. عبّر مبرهنة Tweedie $\mathbb{E}[x_0|x_t]$ بالسكور واربطها بتايلور درجة أولى.

٢٠. تحدٍّ تركيبي: «لماذا أخذ عيّنات Carlo Monte بطيء؟» — اشتقّ $O(1/\sqrt{N})$ من تايلور/تباين، واربطه بخطأ SGD $O(1/\sqrt{T})$، ثمّ ناقش كيف ترفع رتبة (5.11-9) الدقّة.

- **تايلور (1.11):** $P_n(x)=\sum f^{(k)}(a)(x-a)^k/k!$ — تقريب محليّ للدالة الناعمة.
- **البقايا (2.11):** لاغرانج $|R_n|\le M|x-a|^{n+1}/(n+1)!$؛ صيغ تكاملية/بيانو مكمّلة.
- **متعدّد (3.11):** $f(x+h)=f+\nabla^\top h+\frac12 h^\top\nabla^2 f\,h+R_2$ — الهِسّية تحكم الانحناء.
- **خطأ القطع (4.11):** رتبة p تعني $O(h^{p+1})$؛ الفروق المركزية أدقّ من الأمامية.
- **التكيّف (5.11):** $\kappa=|xf'/f|$ يقيس تضخّم الخطأ النسبي؛ $\kappa\gg1$ = مُكيَّف سيّئاً.
- **التطبيقات (6.11):** نيوتن $x-f'/f''$ (تربيعي)؛ Gauss-Newton يقرّب $H\approx J^\top J$؛ autodiff يُنتج معاملات دقيقة؛ Tweedie/score يستخدم السكور من الدرجة الأولى.

الرمز	المعنى	أين عُرّف
P_n	متعدّدة تايلور	(1.11)
R_n	البقايا	(2.11)
$\nabla^2 f$	الهِسّية	(3.11)
$O(h^{p+1})$	رتبة الخطأ	(4.11)
$\kappa(x)$	عدد التكيّف	(5.11)
$J_r^\top J_r$	تقريب GN	(6.11)

١. J. Stewart, (2015). *Calculus*, 8th ed., Cengage — تايلور والبقايا بشكل كلاسيكي.

٢. T. Apostol, (1967). *Calculus, Vol. I*, Wiley — أساس نظري صارم للتوسّعات.

٣. N. Higham, (2002). *Accuracy and Stability of Numerical Algorithms*, 2nd ed., SIAM — تحليل الخطأ والتكيّف (يرتبط بـ ch06).

٤. S. Wright, & J. Nocedal, (2006). *Numerical Optimization*, 2nd ed., Springer — نيوتن/Gauss-Newton والتحسين من الدرجة الثانية.

٥. C. Bishop, (2006). *Pattern Recognition and Machine Learning*, Springer — الهِسّية في التصنيف والتقريب اللاخطي.

٦. I., Goodfellow, A. Courville, & Y. Bengio, (2016). *Deep Learning*, MIT Press — التدرّج، تلاشي/انفجار التدرّج، والتحسين.

٧. L., Bottou, F. Curtis, & J. Nocedal, (2018). *Optimization Methods for Large-Scale Machine Learning*, SIAM Review — تحليل عيّنات SGD ($O(1/\sqrt{T})$).

٨. A., Jacot, F. Gabriel, & C. Hongler, (2018). *Neural Tangent Kernel* (NeurIPS) — تخطيط الشبكة كتايلور خطّي عند العرض اللانهائي.

٩. S. Ermon, & Y. Song, (2019). *Generative Modeling by Estimating Gradients of the data distribution* (score matching/dffiusion) — استخدام السكور ($\nabla \log p$) في التوليد.

المعادلات التفاضلية والنظم الديناميكية

الهدف من الفصل

سادس وأخير فصول الجزء الثاني (التفاضل والتكامل). أنهينا النهايات (7) والمشتقّة (8) والتفاضل المصفوفي (9) والتكامل/القياس (10) وتايلور/الأخطاء (11). الآن نربط الاشتقاق بـ «الزمن»: كيف تتطوّر الكميات؟ المعادلات التفاضلية هي لغة التدفّق — وتعلّم الآلة كلّه نظام ديناميكي: التدريب = تدفّق تدرّجي، وdffiusion = حلّ معادلة تفاضلية عشوائية (SDE) عكسية.

أربعة أسباب تجعل هذا الفصل «بوّابة» نحو الجزء الثالث وما بعده:

١. **التدريب نظام ديناميكي:** نزول التدرّج $\theta_{t+1} = \theta_t - \eta \nabla L$ هو ت discreteة (تقطيع) للمعادلة المستمرّة $\dot{\theta} = -\nabla L(\theta)$ — «تدفّق تدرّجي».

٢. **الاستقرار والتقارب:** تحليل النقاط الثابتة fixed) (points وأحواض الجذب يفسّر لماذا يتقارب النموذج ولماذا قد يعلق في سرج.

٣. **المعادلات الجزئية :(PDE)** الانتشار (dffiusion) = معادلة حرارية؛ أساس نماذج التوليد الحديثة.

٤. **الأنظمة العشوائية:** dffiusion و Langevin و SDE هي «تفاضلية + ضجيج» — الجسر إلى الاحتمالات (الجزء الثالث).

خريطة الفصل

القسم	الموضوع	الأداة المركزية
2.12	المعادلات التفاضلية العادية (ODE)	$\dot{x} = f(t, x)$
3.12	الطرق العددية: أويلر وروﻧﺞ-كوتا	$x_{n+1} = x_n + h\dot{x}_n$
4.12	التحليل الكيفي: النقاط الثابتة والاستقرار	$J = \nabla f(x^*)$
5.12	المعادلات التفاضلية الجزئية (PDE)	$\partial_t u = \alpha \nabla^2 u$
6.12	النظم الديناميكية والتعلّم	$\dot{\theta} = -\nabla L$
7.12	التطبيقات الحديثة: ODE Neural و Dffiusion/SDE	عكسي SDE

التعريف

dir="ltr"> <div

$\dot{x}$ = is condition initial with ODE An **Problem). Value (Initial 1.2.12 Definition** **.autonomous** is it t on depend not does f If .$\dot{x} = dx/dt$ where $f(t, x)$, $x(t_0) = x_0$, neighbourhood, a on x in **Lipschitz** and t in continuous is f If **Theorem. Picard–Lindelöf** solution. local unique a exists there

$$\dot{x} = f(t, x), \quad x(t_0) = x_0. \tag{1.12}$$

النظرية 1.2.12 (صيغ خاصّة):

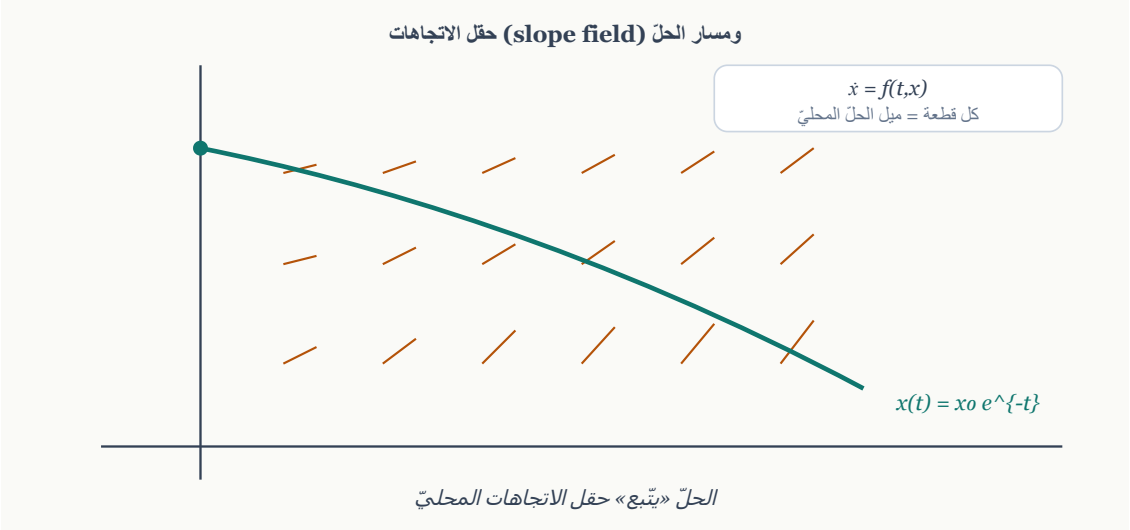
- **قابلة للفصل:** $\frac{dy}{dx} = \frac{g(x)}{h(y)} \Longrightarrow \int h(y)dy = \int g(x)dx$.
- **خطّية من الدرجة الأولى:** $\dot{x} + p(t)x = q(t)$ تُحلّ بعامل التكامل $e^{\int p}$.

جدول الرموز

الرمز	الاسم	المعنى
$\dot{x}$	المشتقّة الزمنية	dx/dt
f	الحقل الاتجاهي	يحدّد «الميل» المحلّي
Lipschitz	شرط انتظام	يضمن الوحيدة

رسم توضيحي

<figure> الشكل<figcaption> 1.12: الحلّ $x(t)$ «يتّبع» حقل الاتجاهات — عند كل نقطة الميل معطى بـ



شكل ١٠١٢: *
حقل اتجاهات ومسار حلّ

$f(t,x)$. الحلّ بمنحنى أخضر يبدأ من $(0, x_0)$ ويتبع الميل المحلّي.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
نسيان شرط البداية	الحلّ غير محدّد بلا x_0	أرفق دائماً IVP
افتراض الوجود دائماً	قد لا يحلّ محلّياً	افحص الانتظام
تجاهل Lipschitz للوحيدة	قد تتعدّد الحلول	تحقّق Lipschitz
خلط مستقل/غير مستقل	$f(x)$ vs $f(t,x)$	صنّف النظام

أمثلة محلولة على المعادلات التفاضلية العادية (15 مثالاً)

مثال (12.2-1).

- **المعطيات:** $\dot{x} = kx$، $x(0) = x_0$.
- **المطلوب:** الحلّ.
- **الحل:**

١. $\frac{dx}{x} = k\,dt \Longrightarrow \ln|x| = kt + C \Longrightarrow x = x_0 e^{kt}$. ■

- **النتيجة:** نموّ/اضمحلال أسّي.
- **الربط بالذكاء الاصطناعي:** «ديناميكا معدّل ثابت» — نموذج لالتواء الاحتمالات ونصف أعمار الأوزان.

مثال (12.2-2).

- **المعطيات:** $\dot{x} = -kx$، $x(0) = 1$.
- **المطلوب:** الحلّ وسلوك $t \to \infty$.
- **الحل:**

١. $x = e^{-kt} \to 0$ لـ $t \to \infty$. ■

- **النتيجة:** اضمحلال.
- **الربط بالذكاء الاصطناعي:** «اضمحلال الوزن» (weight decay) = معادلة من الدرجة الأولى.

مثال (12.2-3).

- **المعطيات:** $\frac{dy}{dx} = \frac{y}{x}$، $y(1) = 2$.
- **المطلوب:** حلّ قابل للفصل.
- **الحل:**

١. $\frac{dy}{y} = \frac{dx}{x} \Longrightarrow \ln y = \ln x + C \Longrightarrow y = cx$؛ من $y(1) = 2$: $c = 2$. ■

- **النتيجة:** $y = 2x$.
- **الربط بالذكاء الاصطناعي:** «تناسب طردي» — أساس ميزات المقياس الخطّي.

مثال (12.2-4).

- **المعطيات:** لوجستيك $\dot{x} = rx(1 - x/K)$، $x(0) = x_0$.
- **المطلوب:** النقاط الثابتة وسلوكها.
- **الحل:**

١. الثوابت: $x = 0$ (غير مستقر)، $x = K$ (مستقر).

٢. الحلّ $x(t) = \frac{Kx_0e^{rt}}{K+x_0(e^{rt}-1)}$. ■

- **النتيجة:** تشبّع عند السعة K.
- **الربط بالذكاء الاصطناعي:** «تشبّع السعي» (sigmoid-like) — يظهر في ديناميكا الشبكات والسكان.

مثال (12.2-5).

- **المعطيات:** $\dot{x} + 2x = e^{-t}$، $x(0) = 0$.
- **المطلوب:** حلّ خطّي بعامل تكامل.
- **الحل:**

١. العامل e^{2t}؛ $(xe^{2t})' = e^t \implies xe^{2t} = e^t - 1 \implies x = e^{-t} - e^{-2t}$. ■

- **النتيجة:** ردّ انتقالي.
- **الربط بالذكاء الاصطناعي:** «استجابة عابرة» — نموذج لاستقرار المحسّن.

مثال (12.2-6).

- **المعطيات:** $\dot{x} = f(x)$ Lipschitz محليّاً، $x(t_0) = x_0$.
- **المطلوب:** ماذا يضمن بيكار-ليندلوف؟
- **الحل:**

١. وجود وحيدة محليّان للحلّ. ■

- **النتيجة:** حلّ فريد قريباً.
- **الربط بالذكاء الاصطناعي:** «تفاضل آلي يُعطي تدرّجاً فريداً» — أساس استقرار مسار التدريب.

مثال (12.2-7).

- **المعطيات:** $\dot{x} = x^{1/3}$، $x(0) = 0$.
- **المطلوب:** هل الحلّ فريد؟
- **الحل:**

١. $f'(0)$ غير منتهٍ $\Rightarrow$ غير Lipschitz عند 0؛ حلول $x = 0$ و $x = (\frac{2}{3}t)^{3/2}$ كلاهما يمرّ بـ 0. ■

- **النتيجة:** تعدّد الحلول — فقدان الوحيدة.
- **الربط بالذكاء الاصطناعي:** «نقاط غير ناعمة» تكسر التحليل — سبب تفضيل التنعيم (smoothing) في الخسائر.

مثال (12.2-8).

- **المعطيات:** مذبذب $\ddot{x} = -\omega^2 x$، $x(0) = A, \dot{x}(0) = 0$.
- **المطلوب:** الحلّ.
- **الحل:**

١. $x(t) = A\cos(\omega t)$. ■

- **النتيجة:** تذبذب دوريّ.
- **الربط بالذكاء الاصطناعي:** «ترددات/اهتزازات» — نموذج لديناميكا الاهتمام الدوري.

مثال (12.2-9).

- **المعطيات:** نظام $\dot{X} = AX$، $X(0) = X_0$.
- **المطلوب:** الحلّ.
- **الحل:**

١. $X(t) = e^{At}X_0$ (أسّ مصفوفي). ■

- **النتيجة:** أسّ مصفوفي.
- **الربط بالذكاء الاصطناعي:** «أسّ مصفوفي = تطوّر خطّي» — يظهر في النظم الديناميكية للشبكات.

مثال (12.2-10).

- **المعطيات:** مشكلة قيمة ابتدائية عامّة.
- **المطلوب:** لماذا البداية ضرورية؟
- **الحل:**

١. الحلّ العامّ يحوي ثوابت تعيين؛ $x(t_0)=x_0$ تحدّدها. ■

- **النتيجة:** بلا شرط بداية الحلّ غير فريد.
- **الربط بالذكاء الاصطناعي:** «التهيئة = شرط ابتدائي» — تحدّد مسار التدريب (NTK) يثبته عند العرض اللانهائي، ch11).

مثال (11-2.12).

- **المعطيات:** معادلة تامّة $M\,dx+N\,dy=0$ مع $\partial M/\partial y=\partial N/\partial x$.
- **المطلوب:** أوجد الدالّة الكمونية Φ.
- **الحل:**

١. $\Phi=\int M\,dx+\int(N-\Phi_y)\,dy$؛ المستويات $\Phi=c$ هي الحلول. ■

- **النتيجة:** منحنيات كمون.
- **الربط بالذكاء الاصطناعي:** «دالّة كمون» = أساس fields conservative والتدرّج من الدرجة الأولى.

مثال (12-2.12).

- **المعطيات:** برنولي $\dot{x}+px=qx^{n}$.
- **المطلوب:** اختزلها خطّية.
- **الحل:**

١. بـ $y=x^{1-n}$ تصبح خطّية. ■

- **النتيجة:** تحويل لخطّي.
- **الربط بالذكاء الاصطناعي:** «تحويل غير خطّي لخطّي» — نموذج لـ feature maps.

مثال (13-2.12).

- **المعطيات:** قارن مستقلّاً $f(x)$ وغير مستقلّ $f(t,x)$.

- **المطلوب:** أثر ذلك على التحليل.
- **الحل:**

١. المستقلّ له مخطّط طور ثابت؛ غير المستقلّ يتغيّر زمنياً. ■

- **النتيجة:** فرق في الاستقرار.
- **الربط بالذكاء الاصطناعي:** «معدّل تعلّم متغيّر زمنياً» (schedule) = نظام غير مستقلّ.

مثال (14-2.12).

- **المعطيات:** $\ddot{x} = f(t, x, \dot{x})$ من الدرجة الثانية.
- **المطلوب:** اختزالها نظاماً من الدرجة الأولى.
- **الحل:**

١. بـ $v = \dot{x}$: $\dot{x} = v,\ \dot{v} = f(t, x, v)$. ■

- **النتيجة:** نظام أبعاد 2.
- **الربط بالذكاء الاصطناعي:** «رفع المرتبة» = زيادة أبعاد الحالة — نمط في النماذج الديناميكية.

مثال (15-2.12).

- **المعطيات:** لماذا ODE في التعلّم؟
- **المطلوب:** اربط بالتدريب.
- **الحل:**

١. التحديث المنفصل $\theta_{k+1} = \theta_k - \eta \nabla L$ هو تقطيع أويلر (3.12) للمستمرّ $\dot{\theta} = -\nabla L$. ■

- **النتيجة:** GD = ODE مقطّعة.
- **الربط بالذكاء الاصطناعي:** «التدرّب كنظام ديناميكي» — خيط الفصل 6.12 بأكمله.

التعريف

dir="ltr"> <div
method: Euler explicit The **Runge–Kutta). & (Euler 1.3.12 Definition**

$$x_n + 1 = x_n + h\, f(t_n, x_n). \tag{2.12}$$

dir="ltr"> <div
has and step per evaluations slope four uses (RK4) Runge–Kutta 4th-order classical The
$O(h^4)$ global ,$O(h^5)$ error local has Euler $O(h^2)$ global ,$O(h)$.

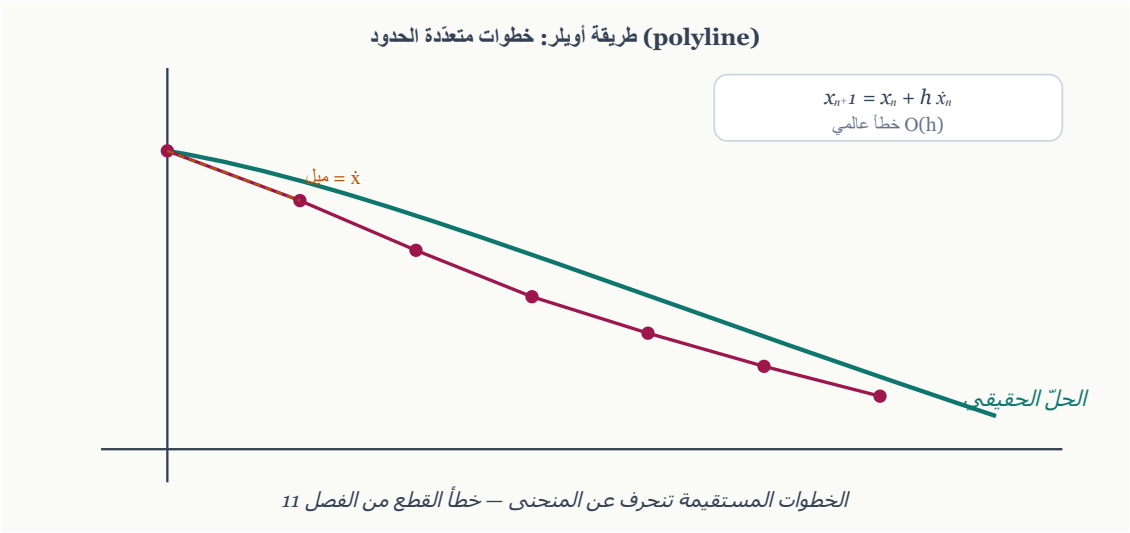
النظرية 1.3.12 (الخطأ): تقسيم الخطوة h ينقص الخطأ العالمي لأويلر بـ $O(h)$؛ لـ RK4 بـ $O(h^4)$.

جدول الرموز

الرمز	الاسم	المعنى
h	حجم الخطوة	دقّة/تكلفة
x_n	التقريب عند t_n	$x_n \approx x(t_n)$
RK4	رونج-كوتا 4	طريقة أعلى رتبة

رسم توضيحي

<figure> الشكل<figcaption> 2.12: أويلر يمشي بخطوات مستقيمة تتبع ميل $\dot{x}$ عند كل نقطة. الحلّ الحقيقي



شكل ٢.١٢: *
خطوات أويلر والميل المحليّ

(أخضر) ينحرف تدريجياً عن المضلّع الأحمر — خطأ القطع (من الفصل <figcaption>.(11 </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اختيار h كبيرة	خطأ/عدم استقرار	اضبط h تجريبياً
نسيان أنّ أويلر $O(h)$ فقط	أبطأ من RK4	استخدم RK4 للمسائل الناعمة
استخدام صريح على «متصلّبة»	قد ينفجر	استخدم ضمنياً
خلط الخطأ المحليّ/العالمي	مختلفان بالرتبة	المحلي $O(h^2)$، العالمي $O(h)$

أمثلة محلولة على الطرق العددية (15 مثالاً)

مثال (12.3-1).

- **المعطيات:** $\dot{x} = -x$، $x(0) = 1$، $h = 0.1$، خطوة واحدة.
- **المطلوب:** تقدير أويلر.
- **الحل:**

١. $x_1 = 1 + 0.1(-1) = 0.9$ (الحقيقي $e^{-0.1} \approx 0.905$). ■

- **النتيجة:** 0.9 (خطأ ≈ 0.005).
- **الربط بالذكاء الاصطناعي:** «خطوة تحديث واحدة» = تحديث SGD واحد — نفس البنية.

مثال (12.3-2).

- **المعطيات:** $\dot{x} = x$، $x(0) = 1$، $h = 0.1$، خطوتان.
- **المطلوب:** أويلر.
- **الحل:**

١. $x_1 = 1.1$، $x_2 = 1.1 + 0.1(1.1) = 1.21$. ■

- **النتيجة:** 1.21 (الحقيقي $e^{0.2} \approx 1.221$).
- **الربط بالذكاء الاصطناعي:** «نموّ مضلّل» — أويلر الصريح يبالغ في النموّ السريع (مثل خطوات تعليم كبيرة).

مثال (12.3-3).

- **المعطيات:** لوجستيك $\dot{x} = x(1 - x)$، $x_0 = 0.1$، $h = 0.2$.
- **المطلوب:** خطوة أويلر.
- **الحل:**

١. $x_1 = 0.1 + 0.2(0.1 \cdot 0.9) = 0.118$. ■

- **النتيجة:** 0.118.
- **الربط بالذكاء الاصطناعي:** «محاكاة ديناميكا الاحتمال» — أساس المحاكاة في التعزيزي.

مثال (12.3-4).

- **المعطيات:** $\dot{x} = -x$ بـ RK4 خطوة $h = 0.1$.
- **المطلوب:** قارن الدقّة بأويلر.
- **الحل:**

١. RK4 يجمع منحدرات عند نقاط عدّة $\Longrightarrow$ خطأ 10^{-5} $\sim$ مقابل 5×10^{-3} لأويلر. ■

- **النتيجة:** أدقّ بمرتين من الرتبة.
- **الربط بالذكاء الاصطناعي:** «تقييم متعدّد» = زيادة دقّة بتكلفة حسابية — مثل عينات متعدّدة.

مثال (3.12-5).

- **المعطيات:** قسّم h إلى النصف.
- **المطلوب:** كيف ينقص الخطأ؟
- **الحل:**

١. لأويلر العالمي $O(h)$ ينقص للنصف؛ لـ RK4 $O(h^4)$ ينقص لـ $1/16$. ■

- **النتيجة:** RK4 أسرع تحسّناً.
- **الربط بالذكاء الاصطناعي:** «تكلفة الدقّة» — توازن batch/epochs.

مثال (3.12-6).

- **المعطيات:** محليّ مقابل عالمي.
- **المطلوب:** اشرح الفرق.
- **الحل:**

١. محليّ لخطوة واحدة $O(h^2)$؛ يتراكم $1/h$ مرّة $\Longrightarrow$ عالمي $O(h)$. ■

- **النتيجة:** فرق رتبة.
- **الربط بالذكاء الاصطناعي:** «تراكم الخطأ» يشبه تراكم انحياز التقدير عبر الخطوات.

مثال (3.12-7).

- **المعطيات:** استقرار أويلر لـ $\dot{x} = \lambda x$.
- **المطلوب:** شرط الاستقرار.
- **الحل:**

١. $h < 2/|\lambda| \Longrightarrow |1 + h\lambda| < 1$ (لـ $\lambda < 0$). ■

- **النتيجة:** حدّ الخطوة.
- **الربط بالذكاء الاصطناعي:** «معدّل التعلّم الأقصى» = نصف قطر استقرار أويلر — نفس قيد GD!

مثال (3.12-8).

- **المعطيات:** أويلر الضمني (backward) $x_{n+1} = x_n + hf(x_{n+1})$.
- **المطلوب:** لماذا أكثر استقراراً؟
- **الحل:**

١. يحلّ معادلة ضمنية $\Rightarrow$ مستقرّ لـ h كبيرة على المتصلّبة. (stffi) ■

- **النتيجة:** A-stable.
- **الربط بالذكاء الاصطناعي:** «تحديث ضمني» = محسّنات المستوى الثاني (Newton) — استقرار بثمن حلّ معادلة.

مثال (12.3-9).

- **المعطيات:** طريقة المنتصف (midpoint) من رتبة 2.
- **المطلوب:** الخطوة.
- **الحل:**

١. $k_1 = hf_n$؛ $k_2 = hf(x_n + \frac{h}{2}, v_n + \frac{k_1}{2})$؛ $x_{n+1} = x_n + k_2$. ■

- **النتيجة:** $O(h^2)$.
- **الربط بالذكاء الاصطناعي:** «تقدير عند منتصف الخطوة» — نموذج لـ lookahead optimizers.

مثال (12.3-10).

- **المعطيات:** طريقة هون (Heun) = شبه منحرف.
- **المطلوب:** الصيغة.
- **الحل:**

١. $x_{n+1} = x_n + \frac{h}{2}(f_n + f(x_n + hf_n))$. ■

- **النتيجة:** رتبة 2.
- **الربط بالذكاء الاصطناعي:** «متوسّط ميلين» = نموذج لـ momentum المتوسط.

مثال (12.3-11).

- **المعطيات:** صريح مقابل ضمني.
- **المطلوب:** متى نفضّل الضمني؟
- **الحل:**

١. عند متصلّبة (eigenvalues كبيرة سالبة) الصريح ينهار؛ الضمني مستقرّ. ■

- **النتيجة:** حسب طيف النظام.
- **الربط بالذكاء الاصطناعي:** «هِسّية شديدة التكيّف» تستدعي محسّنات ضمنية. (ch11)

مثال (12-3.12).

- **المعطيات:** تراكم الخطأ عبر $N = T/h$ خطوة.
- **المطلوب:** الخطأ الكلّي.
- **الحل:**

١. $E_{\text{global}} \approx N \cdot E_{\text{local}} \propto (T/h) \cdot h^2 = Th = O(h)$. ■

- **النتيجة:** عالمي $O(h)$.
- **الربط بالذكاء الاصطناعي:** «عدد الخطوات × خطأ/خطوة» = تحليل عيّنات SGD. (ch11-7)

مثال (13-3.12).

- **المعطيات:** خطوة تكيّفية (embedded RK) مثل RKF45.
- **المطلوب:** الفكرة.
- **الحل:**

١. نركض ترتيبين؛ الفرق يُقدّر الخطأ فنضبط h تلقائياً. ■

- **النتيجة:** دقّة مضمونة بتكلفة أدنى.
- **الربط بالذكاء الاصطناعي:** «تعلّم معدّل تعلّم تكيّفي» (LR schedule) — نفس الفلسفة.

مثال (14-3.12).

- **المعطيات:** تقطيع GD كأويلر.
- **المطلوب:** اربط (15-2.12) رسمياً.
- **الحل:**

١. $\theta_{k+1} = \theta_k - \eta \nabla L(\theta_k)$ = أويلر لـ $\dot{\theta} = -\nabla L$ بخطوة η. ■

- **النتيجة:** GD = ODE مقطّعة.
- **الربط بالذكاء الاصطناعي:** «كلّ محسّن = طريقة عددية لمستمرّ» — بوصلة الفصل 6.12.

مثال (15-3.12).

- **المعطيات:** خطوات متعدّدة (Adams) مقابل خطوة واحدة.
- **المطلوب:** الميزة.
- **الحل:**

١. Adams-Basfhorth يستعيد مشتقّات سابقة ⟹ رتبة أعلى بأقلّ تكلفة/خطوة. ■

- **النتيجة:** كفاءة.
- **الربط بالذكاء الاصطناعي:** «إعادة استخدام حالات سابقة» = نموذج لـ momentum/Adam (لحظات تاريخية).

التعريف

dir="ltr"> <div
.$f(x^*) = 0$ fi **fixed** is x^* point A **stability). & point (Fixed 1.4.12 Definition
Stability $\dot{\xi} = J_f(x^*)\,\xi, \qquad J_f = \nabla f(x^*)$. :$x = x^* + \xi$ via x^* about $\dot{x} = f(x)$ Linearizing
$\Rightarrow \operatorname{Re}\lambda > 0$ any stable; asymptotically $\Rightarrow \operatorname{Re}\lambda < 0$ all :J_f of eigenvalues by determined is
unstable.

$$\dot{\xi} = \nabla f(x^*)\,\xi. \tag{3.12}$$

النظرية 1.4.12 (تصنيف): قيم ذاتية حقيقية متّفقة الإشارة ⟹ عقدة (node)؛ متباينة ⟹ سرج (saddle)؛ مركّبة ⟹ حلزون (spiral)؛ تخيّلية ⟹ مركز.

جدول الرموز

الرمز	الاسم	المعنى
x^*	نقطة ثابتة	$f(x^*)=0$
J_f	يعقوبية الحقل	تحكّم الاستقرار
λ	قيمة ذاتية	$\operatorname{Re}\lambda$ تحدّد الاستقرار

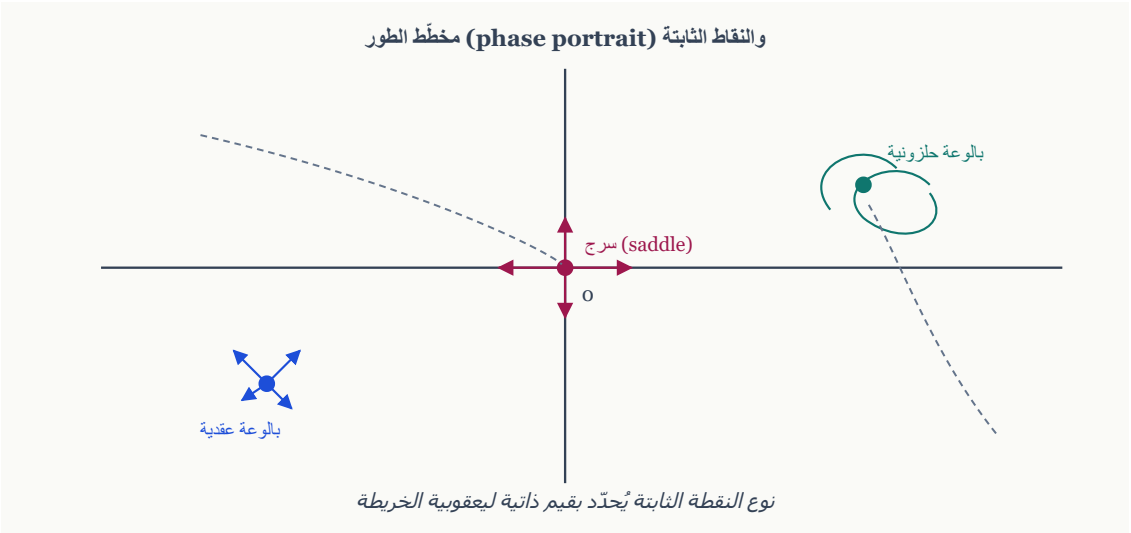
رسم توضيحي

<figure> الشكل<figcaption> 3.12: مخطّط الطور يُظهر ثلاثة أنواع: سرج (أحمر، انحراف+تقارب)، بالوعة حلزونية (أخضر)، بالوعة عقدية (أزرق). التصنيف يُحدّد بقيم ذاتية J_f.</figcaption></figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الحكم بالاستقرار من f لا J	J هو من يقرّر	خطّط $\nabla f(x^*)$
تجاهل الجزء التخيّلي	حلزون لا مركز	فحص $\operatorname{Re}\lambda$
اعتبار كلّ سرج سيّئاً	قد يكون مستقرّ اتجاهياً	تحليل أبعاد
نسيان أنّ التحليل محلّي	بعيداً قد يختلف	أحواض جذب محلية

أمثلة محلولة على النقاط الثابتة والاستقرار (15 مثالاً)



شكل ٣.١٢: *
مخطّط طور بأنواع النقاط الثابتة

مثال (4.12-1).

- **المعطيات:** $\dot{x} = f(x)$، $f(x^*) = 0$.
- **المطلوب:** ما النقطة الثابتة؟
- **الحل:**

١. عند x^* المشتقّة صفر $\Longrightarrow$ لا حركة. ■

- **النتيجة:** توازن.
- **الربط بالذكاء الاصطناعي:** «نقطة ثابتة = حلّ مُثلّث» (تدرّج صفر).

مثال (4.12-2).

- **المعطيات:** $f(x) = x - x^3$.
- **المطلوب:** الثوابت واستقرارها.
- **الحل:**

١. $x^* = 0, \pm 1$؛ $f'(x) = 1 - 3x^2 \Longrightarrow f'(0) = 1 > 0$ (غير مستقر)، $f'(\pm 1) = -2 < 0$ (مستقر). ■

- **النتيجة:** 0 سرج، ± 1 مستقرّان.
- **الربط بالذكاء الاصطناعي:** «حلول محليّة متعدّدة» — نموذج لعدّة مُثلّثات.

مثال (12.4-3).

- **المعطيات:** لوجستيك $\dot{x} = rx(1 - x/K)$.
- **المطلوب:** استقرار 0 و K.
- **الحل:**

١. $f'(x) = r - 2rx/K$؛ $f'(0) = r > 0$ (غير مستقر)، $f'(K) = -r < 0$ (مستقر). ■

- **النتيجة:** السعة K جاذبة.
- **الربط بالذكاء الاصطناعي:** «حوض جذب» = منطقة تجذب التدريب نحو حلّ.

مثال (12.4-4).

- **المعطيات:** بندول $\ddot{\theta} = -\sin\theta$.
- **المطلوب:** الثوابت واستقرارها.
- **الحل:**

١. عند $\theta = 0$ (أسفل، مستقر)، $\theta = \pi$ (أعلى، غير مستقر). ■

- **النتيجة:** توازن مستقر/غير مستقر.
- **الربط بالذكاء الاصطناعي:** «توازنات مستقرة/هشّة» — نموذج لحلول شبكية مختلفة الجودة.

مثال (12.4-5).

- **المعطيات:** سرج-عقدة (saddle-node) $\dot{x} = \mu - x^2$.
- **المطلوب:** ماذا عند $\mu = 0$؟
- **الحل:**

١. لـ $\mu > 0$ ثابتان؛ عند $\mu = 0$ يلتقيان (تفرّع). ■

- **النتيجة:** تفرّع (bfiurcation).
- **الربط بالذكاء الاصطناعي:** «ظهور/اختفاء حلّ عند عتبة» — نموذج لظهور سلوك شبكي.

مثال (12.4-6).

- **المعطيات:** $\dot{x} = Ax$، $A = \begin{bmatrix} -1 & 2 \\ -2 & -1 \end{bmatrix}$.

- **المطلوب:** نوع النقطة.
- **الحل:**

١. $\lambda = -1 \pm 2i \implies$ حلزون جاذب. ■

- **النتيجة:** sink، spiral
- **الربط بالذكاء الاصطناعي:** «تذبذب مُخمَّد» — نموذج لديناميكا التعلّم المتذبذبة.

مثال (12.4-7).

- **المعطيات:** مركز x لـ $\dot{x} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$.
- **المطلوب:** استقرار؟
- **الحل:**

١. $\lambda = \pm i \implies$ مركز (مستقر محايداً لا جذباً). ■

- **النتيجة:** دوريّ لا يتقارب.
- **الربط بالذكاء الاصطناعي:** «حلقة حدّية» — نموذج لسلوك متكرّر لا يتقارب.

مثال (12.4-8).

- **المعطيات:** عقدة جاذبة $A = \operatorname{diag}(-2, -3)$.
- **المطلوب:** سلوك.
- **الحل:**

١. $\lambda = -2, -3$ سالبتان $\implies$ تقارب أسيّ أحاديّ الاتجاه. ■

- **النتيجة:** sink، node
- **الربط بالذكاء الاصطناعي:** «تقارب سلس» = تدريب مستقر دون تذبذب.

مثال (12.4-9).

- **المعطيات:** $V(x) = x^2$ لـ $\dot{x} = -x$.
- **المطلوب:** أثبت أنّها دالّة ليانوف.
- **الحل:**

١. $\dot{V} = 2x\dot{x} = -2x^2 < 0$ لـ $x \neq 0 \implies$ استقرار. ■

- **النتيجة:** ليانوف تُثبت الاستقرار بلا حلّ صريح.
- **الربط بالذكاء الاصطناعي:** «الخسارة كليانوف» — أساس 6.12.

مثال (10-4.12).

- **المعطيات:** نظام تدرّجي $\dot{x} = -\nabla U(x)$.
- **المطلوب:** هل دائماً يتقارب لأدنى؟
- **الحل:**

١. $\frac{d}{dt}U = -\|\nabla U\|^2 \leq 0$ ⟹ يتناقص حتى $\nabla U = 0$. ■

- **النتيجة:** يتقارب لمُثلّث.
- **الربط بالذكاء الاصطناعي:** «كلّ تدريب = نزول نحو أدنى» — أساس التحسين.

مثال (11-4.12).

- **المعطيات:** حوض جذب (basin).
- **المطلوب:** عرّفه.
- **الحل:**

١. مجموعة النقاط التي تنتهي عند نفس x^* تحت الديناميكا. ■

- **النتيجة:** منطقة جذب.
- **الربط بالذكاء الاصطناعي:** «حوض التعلّم» — يفسّر حساسية التهيئة للحلّ النهائي.

مثال (12-4.12).

- **المعطيات:** لوتكا-فولتيرا (فريسة-مفترس).
- **المطلوب:** نوع التوازن.
- **الحل:**

١. عند التوازن دورات مركزية (لا تقارب) — تذبذب دوريّ. ■

- **النتيجة:** cycles.
- **الربط بالذكاء الاصطناعي:** «ديناميكا تنافسية» — نموذج لأسواق/وكلاء متعدّدين.

مثال (13-4.12).

- **المعطيات:** تفرّع هوبف (Hopf).

- **المطلوب:** اشرح.
- **الحل:**

١. عند عتبة تدخل قيمة ذاتية عبر المحور التخيّلي $\Longrightarrow$ تولد حلقة حدّية. ■

- **النتيجة:** ظهور تذبذب.
- **الربط بالذكاء الاصطناعي:** «انهيار الاستقرار $\Longrightarrow$ سلوك دوري» — نموذج لتذبذب النموذج.

مثال (14-4.12).

- **المعطيات:** استقرار توازن تدريب الشبكة.
- **المطلوب:** اربط بـ J للخسارة.
- **الحل:**

١. عند مُثلّث، هِسّية $\nabla^2 L \succ 0$ (موجبة) $\Longrightarrow$ جاذب محلّي. ■

- **النتيجة:** استقرار محلّي.
- **الربط بالذكاء الاصطناعي:** «هِسّية موجبة = حوض» — يربط 4.12 بـ 4.11.

مثال (15-4.12).

- **المعطيات:** ديناميكا إجماع (consensus) $\dot{x}_i = \sum_j (x_j - x_i)$.
- **المطلوب:** التوازن وسلوكه.
- **الحل:**

١. التوازن عند x_i متساوية، المصفوفة Laplacian لها قيم سالبة عدا صفراً $\Longrightarrow$ إجماع مستقر. ■

- **النتيجة:** تتقارب كلّها لقيمة واحدة.
- **الربط بالذكاء الاصطناعي:** «طبقات التجميع/المتوسّط» = ديناميكا إجماع — أساس GNN والفلاتر.

التعريف

dir="ltr"> <div

Definition 1.5.12 (Heat / Wave / Laplace). The three classical PDEs on $u(x)$ or $u(x,t)$:

- **Heat (dffiusion):** $\partial_t u = \alpha \nabla^2 u$.
- **Wave:** $\partial_{tt} u = c^2 \nabla^2 u$.
- **Laplace / Poisson:** $\nabla^2 u = 0$ (or $= f$).

$$\partial_t u = \alpha \nabla^2 u. \tag{4.12}$$

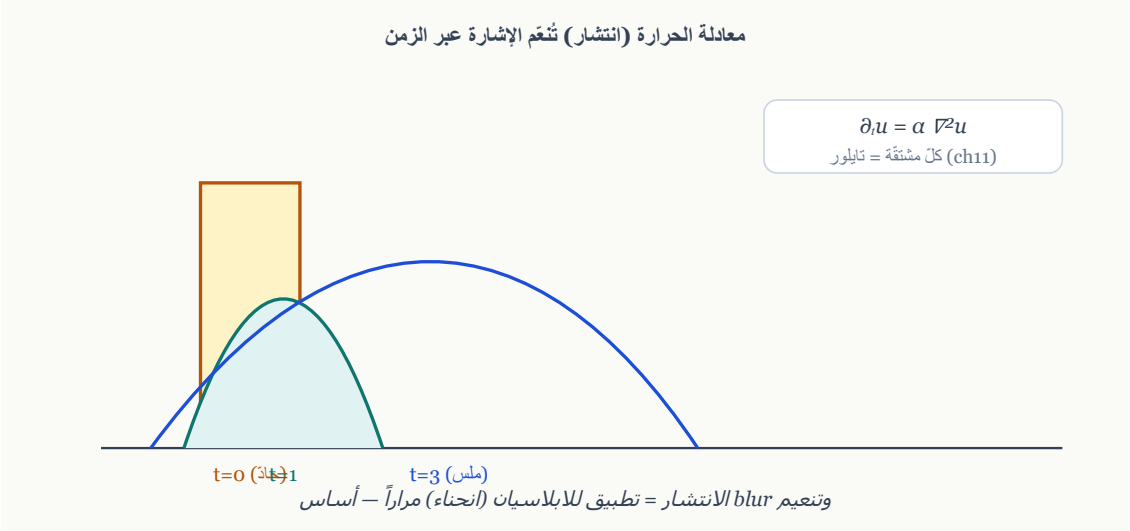
النظرية 1.5.12 (مبدأ أقصى/أسّ حراري): حلّ معادلة الحرارة لا يملك قيمة قصوى داخلية — يتبع «انسياب» من الحدود؛ وحلّها الأسّي هو نواة غاوسية.

جدول الرموز

الرمز	الاسم	المعنى
u	الحقل	دالة في المكان/الزمان
∇^2	اللابلاسيان	مجموع المشتقّات الثانية
α	معامل الانتشار	سرعة التلّس

رسم توضيحي

<figure> الشكل<figcaption> 4.12: معادلة الحرارة تحوّل نتوءاً حادّاً (t=0) إلى منحنى ملَس مع الزمن. كلّ خطوة



شكل ٤.١٢: *
معادلة الحرارة تنعّم إشارة

تطبّق اللابلاسيان (انحناء) — أساس الـ blur والتنعيم.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط ∇^2 مع ∇	لابلاسيان ليس تدرّجاً	مشتقّات ثانية
نسيان شروط الحدود	الحلّ غير فريد	حدد Dirichlet/Neumann
اعتبار الحرارة عكسيةً سهلة	غير محدّبة	مشكلة مطروحة سيّئة
تجاهل البعد الزمني	PDE متعدّدة	افصل متغيرات

أمثلة محلولة على المعادلات التفاضلية الجزئية (15 مثالاً)

مثال (12.5-1).

- **المعطيات:** $\partial_t u = \alpha u_{xx}$ على خطّ.
- **المطلوب:** تفسير.
- **الحل:**

١. معدّل التغيّر = α × الانحناء المحليّ. ■

- **النتيجة:** انتشار.
- **الربط بالذكاء الاصطناعي:** «تلطيف» (smoothing) = نواة التفاف — أساس الطبقات التلافيفية.

مثال (12.5-2).

- **المعطيات:** حالة سكون $\nabla^2 u = 0$.
- **المطلوب:** خصائص.
- **الحل:**

١. لا قيم قصوى داخلية؛ الحلّ يُحدَّد بحدوده. ■

- **النتيجة:** توازن توافقي.
- **الربط بالذكاء الاصطناعي:** «تكميل» (inpainting) = حلّ لابلاس بحدود معروفة.

مثال (12.5-3).

- **المعطيات:** موجية $u_{tt} = c^2 u_{xx}$.
- **المطلوب:** الحلّ العامّ.
- **الحل:**

١. $u(x,t) = F(x-ct) + G(x+ct)$ (موجتان متعاكستان). ■

- **النتيجة:** انتقال بسرعة c.
- **الربط بالذكاء الاصطناعي:** «انتشار إشارات» — نموذج لديناميكا التسلسلات.

مثال (5.12-4).

- **المعطيات:** فصل المتغيرات لـ حرارية على $[0, L]$.
- **المطلوب:** الصيغة.
- **الحل:**

١. $u = X(x)T(t)$، $\implies T'/T = \alpha X''/X = -\lambda$ أوضاع جيبية مُتضائلة. ■

- **النتيجة:** سلسلة فوريه.
- **الربط بالذكاء الاصطناعي:** «تحليل أوضاع» = أساس تحليل التردّدات (FFT).

مثال (5.12-5).

- **المعطيات:** الحلّ الأسّي للحرارية.
- **المطلوب:** عبّره.
- **الحل:**

١. $u(x,t) = \frac{1}{\sqrt{4\pi\alpha t}} e^{-x^2/(4\alpha t)}$. ■

- **نتيجة:** غاوسي يتمدّد.
- **الربط بالذكاء الاصطناعي:** «نواة غاوسية = انتشار» — تظهر في forwards dffiusion (7.12).

مثال (6.12-5).

- **المعطيات:** مبدأ الأقصى.
- **المطلوب:** استنتج.
- **الحل:**

١. لو بلغ القصوى داخلاً لكان $u_{xx} \leq 0$ متناقضاً مع $u_t = 0$ عند أقصى مستقرّ. ■

- **النتيجة:** القيمة القصوى على الحدود.
- **الربط بالذكاء الاصطناعي:** «لا ذروة داخلية» — يفسّر سلوك الحقول الملساء.

مثال (7.12-5).

- **المعطيات:** نواة الانتشار = غاوسي.
- **المطلوب:** اربط بـ (5-5.12).
- **الحل:**

١. الالتفاف بغاوس $e^{\alpha t \nabla^2}$ = يُلَيِّس الإشارة. ■

- **النتيجة:** blur غاوسي.

- **الربط بالذكاء الاصطناعي:** «التشويش الغاوسي المُضاف تدريجياً» هو انتشار (dffiusion) فعلياً (7.12).

مثال (8-5.12).

- **المعطيات:** شروط Dirichlet $u|_{\partial} = g$ مقابل Neumann $\partial_n u|_{\partial} = h$.
- **المطلوب:** الفرق.
- **الحل:**

١. Dirichlet يثبّت القيمة على الحدّ، Neumann يثبّت التدفّق (المشتقّة). ■

- **النتيجة:** نوعان من الحدود.

- **الربط بالذكاء الاصطناعي:** «قناع/حدود» = أنواع شروط في معالجة الصور.

مثال (9-5.12).

- **المعطيات:** بواسون $\nabla^2 u = f$.
- **المطلوب:** متى تُستخدم؟
- **الحل:**

١. عند وجود «مصدر» f (شحنة، كتلة). ■

- **النتيجة:** توازن بمنبع.

- **الربط بالذكاء الاصطناعي:** «حقل بمناطق اهتمام» — نموذج لخريطة حرارة بؤر.

مثال (10-5.12).

- **المعطيات:** الحرارية كـ blur.
- **المطلوب:** اربط بمعالجة الصور.
- **الحل:**

١. كلّ خطوة $u \leftarrow u + \alpha \nabla^2 u$ = التفاف بـ نواة تنعيم. ■

- **النتيجة:** blur تدريجي.

- **الربط بالذكاء الاصطناعي:** «طبقة تلافيفية = انتشار منفصل» — رؤية حاسوبية.

مثال (11-5.12).

- **المعطيات:** إزالة ضجيج بـ PDE.
- **المطلوب:** الطريقة.
- **الحل:**

١. حلّ عكسيّ للحرارية (مطروح سيّء) أو استخدم متباعدة total variation). ■

- **النتيجة:** تنقية.
- **الربط بالذكاء الاصطناعي:** «denoising» — سلف dffiusion الحديث (7.12).

مثال (12-5.12).

- **المعطيات:** انتشار-تفاعل (Turing).
- **المطلوب:** الفكرة.
- **الحل:**

١. تفاعل+انتشار يولّد أنماطاً (بقع) من اضطراب منتظم. ■

- **النتيجة:** أنماط.
- **الربط بالذكاء الاصطناعي:** «ظهور بنى» — نموذج لنشوء ميزات في الشبكات.

مثال (13-5.12).

- **المعطيات:** معادلة فوكر-بلانك للكثافة $p(x,t)$.
- **المطلوب:** اربط بالانتشار.
- **الحل:**

١. تصف تطوّر توزيع جسيمات تتبع SDE — PDE» لتوزيع» (7.12). ■

- **النتيجة:** ديناميكا التوزيع.
- **الربط بالذكاء الاصطناعي:** «كيف يتطوّر توزيع البيانات» — جوهر dffiusion.

مثال (14-5.12).

- **المعطيات:** اضمحلال وضع فوريه.

- **المطلوب:** سلوك كلّ تردّد.
- **الحل:**

١. الوضع e^{ikx} يضمحلّ بـ $e^{-\alpha k^2 t} \Longrightarrow$ الترددات العالية تختفي أوّلاً. ■

- **النتيجة:** تنعيم تردّدي.
- **الربط بالذكاء الاصطناعي:** «low-pass filtering» — يفسّر لماذا الانتشار يمسح التفاصيل.

مثال (15-5.12).

- **المعطيات:** لابلاسيان منفصل على شبكة.
- **المطلوب:** الصيغة.
- **الحل:**

١. $\nabla^2 u \approx u_{i+1} + u_{i-1} + u_{j+1} + u_{j-1} - 4u_{i,j}$ (جار الجذر). ■

- **النتيجة:** التفاف 3×3.
- **الربط بالذكاء الاصطناعي:** «نواة لابلاسيان» = مرشّح حواف كلاسيكي في الرؤية.

التعريف

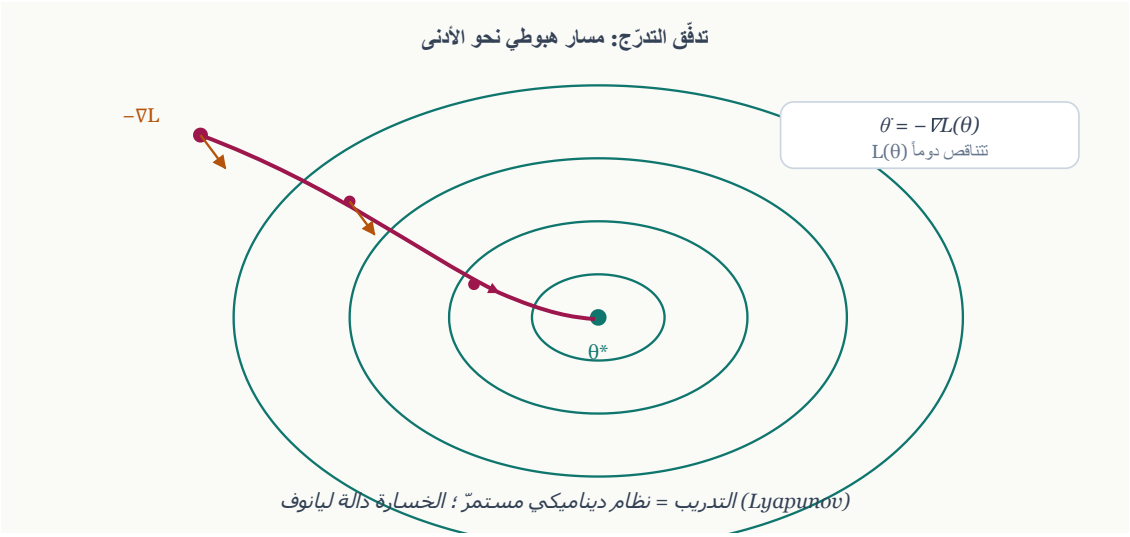
dir="ltr"> <div
the is descent gradient by model a Training **flow).** **(Gradient 1.6.12 Definition**
loss the flow this Along $\dot{\theta} = -\nabla L(\theta)$. :**flow gradient** continuous-time the of discretization
$\frac{d}{dt} L(\theta(t)) = \langle \nabla L, \dot{\theta} \rangle = -\|\nabla L\|^2 \leq 0$. monotonically: decreases

$$\dot{\theta} = -\nabla L(\theta), \qquad \frac{dL}{dt} = -\|\nabla L\|^2. \tag{5.12}$$

النظرية 1.6.12 (ليانوف): $L(\theta)$ نفسها دالّة ليانوف — تنخفض دوماً وتستقرّ عند نقطة حرجة. الانتقال المنفصل (خطوات محدودة) قد يتجاوز الحدّ الأدنى أو يعلق في سرج (تُنقذه الضوضاء).

جدول الرموز

الرمز	الاسم	المعنى
$\theta(t)$	مسار المعاملات	تطوّر التدريب
L	الخسارة	دالّة ليانوف
$\|\nabla L\|^2$	معدّل الهبوط	سرعة التقارب



شكل ٥.١٢: *
تدفّق تدرّجي هابط

رسم توضيحي

<figure> الشكل<figcaption> 5.12: مسار $\theta(t)$ يهبط عبر خطوط متساويات الخسارة نحو الأدنى θ^*. اتجاه الخطوة هو $-\nabla L$ (برتقالي)؛ الخسارة تَنقص رتيباً (ليانوف).</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اعتبار GD تتقارب دائماً لأدنى عامّ	قد تعلق في سرج/محلّي	تفحص المشهد
نسيان أثر الخطوة المنفصلة	المستمرّ يختلف تماماً flow gradient ≠ GD	
تجاهل الضجيج في SGD	يغير الديناميكا	ضوضاء + flow = SGD
خلط تقارب نقطة بحوض	محلّي vs عامّ	حوض جذب محلّي

أمثلة محلولة على النظم الديناميكية والتعلّم (15 مثالاً)

مثال (12.6-1).

- **المعطيات:** $\dot{\theta} = -\nabla L$.
- **المطلوب:** عرّف تدفّق التدرّج.
- **الحل:**

١. مسار مستمرّ «ينزلق» نحو أدنى L. ■

- **النتيجة:** هبوط رتيب.
- **الربط بالذكاء الاصطناعي:** «النموذج = نظام هابط» — القلب النظري للتحسين.

مثال (12.6-2).

- **المعطيات:** أثبت $dL/dt \le 0$.
- **المطلوب:** اشتقّ.
- **الحل:**

١. السلسلة: $\dot{L} = \nabla L^\top \dot{\theta} = -\|\nabla L\|^2 \le 0$. ■

- **النتيجة:** ليانوف مُثبت.
- **الربط بالذكاء الاصطناعي:** «الخسارة تَنقص كلّ خطوة» = ضمان التدريب (نظرياً).

مثال (12.6-3).

- **المعطيات:** GD المنفصل $\theta_{k+1} = \theta_k - \eta \nabla L$.
- **المطلوب:** اربطه بـ أويلر (12.3).
- **الحل:**

١. = أويلر للمستمرّ بخطوة η. ■

- **النتيجة:** GD = ODE مقطّعة.
- **الربط بالذكاء الاصطناعي:** «كلّ محسّن = طريقة عددية» — بوصلة التحسين.

مثال (12.6-4).

- **المعطيات:** SGD كـ flow gradient + ضوضاء.
- **المطلوب:** الصيغة.
- **الحل:**

١. $\dot{\theta} = -\nabla L(\theta) + \sigma(\theta, t)\,\xi(t)$ (SDE). ■

- **النتيجة:** flow عشوائيّ.
- **الربط بالذكاء الاصطناعي:** «SGD = تدفّق مُضطرب» — يشرح الهروب من السرج.

مثال (12.6-5).

- **المعطيات:** زخم (heavy ball) $\ddot{\theta} + \gamma\dot{\theta} = -\nabla L$.

- **المطلوب:** اربطه بنظام من الدرجة الثانية.
- **الحل:**

١. تفاضل زمنيّ ثانٍ بماصّة γ — يكتسب زخماً. ■

- **النتيجة:** ODE مرتبة 2.
- **الربط بالذكاء الاصطناعي:** «momentum» = قصور ذاتي يسرّع التقارب.

مثال (6-6.12).

- **المعطيات:** نيستيروف المُسرّع.
- **المطلوب:** علاقته بالزخم.
- **الحل:**

١. يقارب عند «نقطة تطلّع» مستقبلية $\Rightarrow$ أسرع (تقارب $O(1/k^2)$). ■

- **النتيجة:** تسريع.
- **الربط بالذكاء الاصطناعي:** «التطلّع للمستقبل» = نيستيروف — معيار التسريع.

مثال (7-6.12).

- **المعطيات:** هروب من سرج بالضوضاء.
- **المطلوب:** كيف؟
- **الحل:**

١. الاتجاه السالب-المعياري (instability) يضخّم الضجيج $\Rightarrow$ خروج من السرج. ■

- **النتيجة:** الضجيج منقذ.
- **الربط بالذكاء الاصطناعي:** «لماذا SGD أفضل من «GD — الضجيج يكسر السروج.

مثال (8-6.12).

- **المعطيات:** حوض جذب لمُثلّث.
- **المطلوب:** ما يحدّده؟
- **الحل:**

١. التهيئة θ_0 ضمن الحوض $\Rightarrow$ تنتهي عند نفس الحلّ. ■

- **النتيجة:** حساسية للتهيئة.
- **الربط بالذكاء الاصطناعي:** «حوض التعلّم» يفسّر تباين النتائج بتهيئة مختلفة.

مثال (12.6-9).

- **المعطيات:** حادّة مقابل تسطّح المُثلّث.
- **المطلوب:** علاقتها بالتعميم.
- **الحل:**

١. هِسّية مسطّحة (قيم ذاتية صغيرة) $\perp$ تعميم أفضل غالباً. ■

- **النتيجة:** تسطّح = تعميم.
- **الربط بالذكاء الاصطناعي:** «Sharpness-Aware Minimization» تحسّن التعميم عبر المشهد.

مثال (12.6-10).

- **المعطيات:** ديناميكا رأي/إجماع.
- **المطلوب:** اربط بـ (12.4-15).
- **الحل:**

١. كلّ عقدة تقترب من جيرانها $\Longrightarrow$ إجماع = تدفّق تدرّجي على Laplacian. ■

- **النتيجة:** توافق.
- **الربط بالذكاء الاصطناعي:** «تجميع GNN» = انتشار معلومات ديناميكي.

مثال (12.6-11).

- **المعطيات:** شبكة هوبفيلد.
- **المطلوب:** ديناميكيتها.
- **الحل:**

١. $\dot{s}_i = -\sum_j w_{ij} s_j$ تنزل طاقة $E = -\frac{1}{2} s^\top W s$ $\Longrightarrow$ تستقرّ عند ذاكرة. ■

- **النتيجة:** طاقة تَنقص.
- **الربط بالذكاء الاصطناعي:** «شبكات تذكّر» = نظام ديناميكي بطاقة ليانوف.

مثال (12.6-12).

- **المعطيات:** ليانوف لـ GD.
- **المطلوب:** أثبت التقارب.
- **الحل:**

١. L تَنقص رتيباً ومحدودة أسفل $\Longrightarrow$ تتقارب لـ $\nabla L = 0$. ■

- **النتيجة:** تقارب نظري.
- **الربط بالذكاء الاصطناعي:** «لماذا يتقارب التدريب» — ضمان أساسي.

مثال (13-6.12).

- **المعطيات:** زمن التقارب لـ $\nabla^2 L \succ \mu I$.
- **المطلوب:** قدّره.
- **الحل:**

١. المستمرّ يتقارب أُسّياً بـ معدّل μ (محدّب مكتنز). ■

- **النتيجة:** $O(e^{-\mu t})$.
- **الربط بالذكاء الاصطناعي:** «سرعة التقارب تتبع التكيّف» — يربط بـ 6.11.

مثال (14-6.12).

- **المعطيات:** حدّ متوسط الحقل (mean-field).
- **المطلوب:** الفكرة.
- **الحل:**

١. مع عرض$\to\infty$، معاملات الشبكة تتبع ODE حتمية (لا ضجيج). ■

- **النتيجة:** تحديد حتمي.
- **الربط بالذكاء الاصطناعي:** متوسط/NTK» الحقل» يحوّل الشبكة لنظام ODE (ch11.11-7).

مثال (15-6.12).

- **المعطيات:** الشبكة تحوّل البيانات كتدفّق.
- **المطلوب:** اربط.
- **الحل:**

١. كلّ طبقة = خطوة تدفّق يحوّل توزيع الدخل نحو قابل للفصل. ■

- **النتيجة:** تدفّق تحويلي.
- **الربط بالذكاء الاصطناعي:** «تحويل الميزات تدريجياً» = أساس learning، representation

النظريات والصيغ

dir="ltr"> <div

a defines ODE Neural A **SDE). Dffiusion & ODE (Neural 1.7.12 Theorem**
(VP) Variance-Preserving A $\frac{dz}{dt} = f_\theta(z,t), \quad z(0) = z_0$. by model continuous-depth
(Anderson) SDE reverse-time with $dx = -\frac{1}{2}\beta(t)\,x\,dt + \sqrt{\beta(t)}\,dW$, SDE forward has dffiusion
$dx = \big[-\frac{1}{2}\beta(t)x - \beta(t)\,\nabla_x \log p_t(x)\big]dt + \sqrt{\beta(t)}\,d\bar{W}$.

$$\text{ODE: Neural} \dot{z} = f_\theta(z,t); \qquad \text{reverse: VP-SDE} dx = \big[-\tfrac{1}{2}\beta x - \beta \nabla \log p\big]dt + \sqrt{\beta}\,d\bar{W}. \tag{6.12}$$

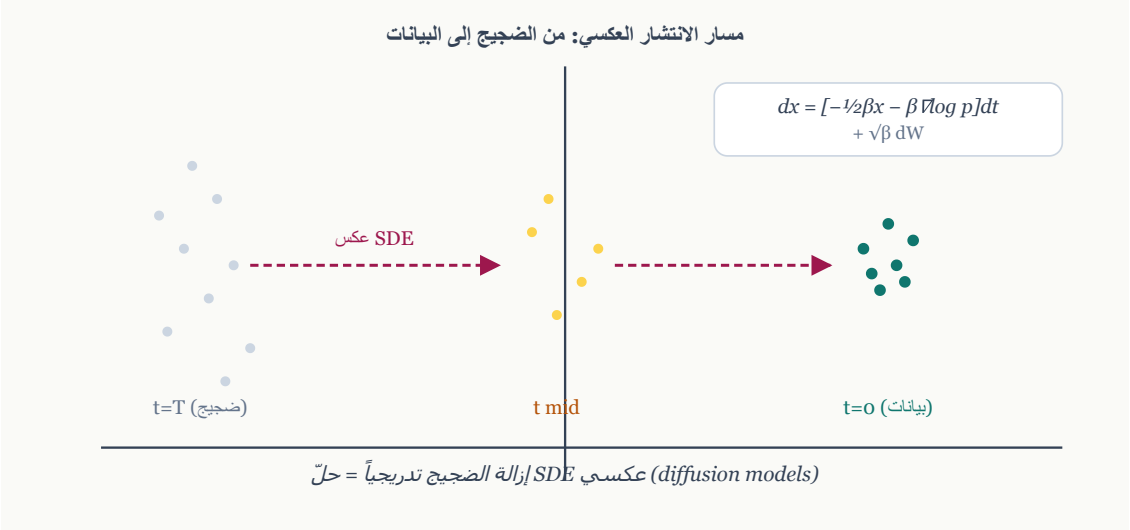
النظرية 1.7.12 (الطريقة المُلحَقة/Adjoint): تفاضل ODE Neural يُحسب بتكامل عكسي لمعادلة مُلحَقة — ذاكرة $O(1)$ لا $O(\text{depth})$.

جدول الرموز

الرمز	الاسم	المعنى
f_θ	شبكة التدفّق	تحكم dz/dt
$\beta(t)$	جدول الضجيج	سرعة الانتشار
$\nabla \log p$	السكور	يقود الإزالة العكسية

رسم توضيحي

<figure> الشكل<figcaption> 6.12: مسار الانتشار العكسي يبدأ من ضجيج (t=T) وينتهي عند بيانات (t=0).



شكل ٦.١٢: *
مسار الانتشار العكسي من الضجيج للبيانات

القيادة بواسطة السكور $\nabla \log p_t$ عبر SDE عكسي — قلب نماذج التوليد الحديثة.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط المستقبل بالماضي في SDE	الاتجاه يقلب الإشارة	استخدم صيغة أندرسون العكسية
نسيان أنّ ODE Neural «بلا عمق»	عمقه = الزمن	الحلّ العددي يحدّه
اعتبار السكور معروفاً	يُعلَّم بـ matching score	تعلّم $\nabla \log p$
تجاهل استقرار أويلر-مارویاما	قد ينفجر	اضبط خطوة التقدير

أمثلة محلولة على التطبيقات الحديثة (15 مثالاً)

مثال (12.7-1).

- **المعطيات:** ODE Neural $\dot{z} = f_\theta(z, t)$ من z_0.
- **المطلوب:** ما «العمق» هنا؟
- **الحل:**

١. العمق = الزمن T؛ الحلّ $z(T) = z_0 + \int_0^T f_\theta \, dt$. ■

- **النتيجة:** عمق مستمرّ.
- **الربط بالذكاء الاصطناعي:** «شبكة لا نهائية الطبقات» — وفّر ذاكرة عبر solver ODE.

مثال (12.7-2).

- **المعطيات:** التفاضل المُلحَق (adjoint).
- **المطلوب:** كيف يتفادى التكلفة؟
- **الحل:**

١. يكامل معادلة مُلحَقة عكسية $\Longrightarrow$ ذاكرة ثابتة بغضّ النظر عن T. ■

- **النتيجة:** $O(1)$ ذاكرة.
- **الربط بالذكاء الاصطناعي:** «تدريب نموذج مستمرّ» بلا تخزين كلّ خطوة — مفتاح Neural ODE.

مثال (12.7-3).

- **المعطيات:** تدفّق تطبيعي مستمرّ (CNF).
- **المطلوب:** كيف يُعلَّم؟
- **الحل:**

١. نغيّر p_0 (ضجيج) إلى p_1 (بيانات) بتدفّق، نُعلّم بـ Jacobian log-det (قاعدة 5.9). ■

- **نتيجة:** نموذج كثافة.
- **الربط بالذكاء الاصطناعي:** «تعيين بيانات↔ضجيج» — أساس التوليد الاحتمالي.

مثال (12.7-4).

- **المعطيات:** SDE أمامي VP.
- **المطلوب:** اكتبه.
- **الحل:**

١. $dx = -\frac{1}{2}\beta(t)x\,dt + \sqrt{\beta(t)}\,dW$. ■

- **النتيجة:** إضافة ضجيج تدريجي.
- **الربط بالذكاء الاصطناعي:** «عملية التشويش» = تدريب dffiusion.

مثال (12.7-5).

- **المعطيات:** عند $t = T$ كبيرة، $x_T \approx \mathcal{N}(0, I)$.
- **المطلوب:** لماذا؟
- **الحل:**

١. الحلّ $x_t = e^{-\frac{1}{2}\int\beta} x_0 + \int \sqrt{\beta}\,dW \Longrightarrow$ التباين يتراكم للضجيج. ■

- **نتيجة:** نهاية ضجيج محض.
- **الربط بالذكاء الاصطناعي:** «العيّنة المولّدة تبدأ من ضجيج» — dffiusion. in sampling

مثال (12.7-6).

- **المعطيات:** SDE عكسي لإزالة الضجيج.
- **المطلوب:** اكتبه.
- **الحل:**

١. $dx = [-\frac{1}{2}\beta x - \beta\nabla \log p_t]dt + \sqrt{\beta}\,d\bar{W}$ (من 12.6). ■

- **نتيجة:** يقوده السكور.
- **الربط بالذكاء الاصطناعي:** «الخطوة العكسية» = توليد صورة من ضجيج.

مثال (12.7-7).

- **المعطيات:** مطابقة السكور (score matching).
- **المطلوب:** ما المُعلَّم؟
- **الحل:**

١. نعلّم شبكة $s_\theta \approx \nabla_x \log p_t(x)$ عبر فقدان سكور. ■

- **نتيجة:** تقدير السكور.
- **الربط بالذكاء الاصطناعي:** «score» = مشتقّة لوغ-كثافة» (tie 11.7-8) يقود diffusion.

مثال (12.7-8).

- **المعطيات:** توبيدي (Tweedie) لإزالة الضجيج.
- **المطلوب:** الصيغة.
- **الحل:**

١. $\mathbb{E}[x_0|x_t] = x_t + \beta_t \nabla \log p_t(x_t)$ (من 11.7-12). ■

- **نتيجة:** خطوة تنظيف.
- **الربط بالذكاء الاصطناعي:** «تقدير البيانات النظيفة» = جوهر خطوة denoising.

مثال (12.7-9).

- **المعطيات:** أويلر-ماروياما لـ SDE.
- **المطلوب:** الصيغة.
- **الحل:**

١. $x_{n+1} = x_n + f_n h + g_n \sqrt{h}\, Z_n,\ Z_n \sim \mathcal{N}(0,1)$. ■

- **نتيجة:** تقدير عشوائيّ.
- **الربط بالذكاء الاصطناعي:** «توليد عيّنة» = خطوات عشوائية عكسية.

مثال (12.7-10).

- **المعطيات:** معادلة فوكر-بلانك للكثافة.

- **المطلوب:** اربط بـ (13-5.12).
- **الحل:**

١. تصف $\partial_t p = \nabla \cdot (\frac{1}{2}\beta x p + \beta p \nabla \log p)$ — تطوّر التوزيع. ■

- **نتيجة:** PDE للتوزيع.
- **الربط بالذكاء الاصطناعي:** «كيف يتطوّر توزيع العيّنات» — مقياس توليد dffiusion.

مثال (11-7.12).

- **المعطيات:** لانغفين MCMC كـ SDE.
- **المطلوب:** الصيغة.
- **الحل:**

١. $x_{k+1} = x_k + \eta \nabla \log p(x_k) + \sqrt{2\eta}\, Z$ (من 11.7-7). ■

- **نتيجة:** مشي عشوائي موجّه.
- **الربط بالذكاء الاصطناعي:** «أخذ عيّنات من التوزيع» = تقدير مونت كارلو عبر SDE.

مثال (12-7.12).

- **المعطيات:** مطابقة التدفّق (flow matching).
- **المطلوب:** الفكرة.
- **الحل:**

١. نعلّم حقل سرعة v_θ يطابق مسار نقل أمثل من ضجيج لبيانات. ■

- **نتيجة:** بديل لـ dffiusion.
- **الربط بالذكاء الاصطناعي:** «تدفّق مستمرّ للتوليد» — أسرع من SDE أحياناً.

مثال (13-7.12).

- **المعطيات:** ODE احتمالي التدفّق (probability flow).
- **المطلوب:** ما ميزته؟
- **الحل:**

١. مسار حتميّ بنفس هندسة السكور (بلا ضجيج) $\Longrightarrow$ توليد حتميّ قابل للتحكّم. ■

- **نتيجة:** sampling. deterministic
- **الربط بالذكاء الاصطناعي:** «توليد حتميّ» — استقرار أعلى من SDE.

مثال (12.7-14).

- **المعطيات:** حفظ مقابل انفجار التباين في SDE.
- **المطلوب:** الفرق.
- **الحل:**

١. VP تحفظ تباين الضجيج بـ β مضبوط؛ VE يتركه ينفجر (يتطلّب جدولة). ■

- **نتيجة:** استقرار الجدولة.
- **الربط بالذكاء الاصطناعي:** «جدولة الضجيج» = hyperparameter حاسم في dffiusion.

مثال (12.7-15).

- **المعطيات:** نواة التماس العصبية كـ limit.
- **المطلوب:** اربط بـ ODE.
- **الحل:**

١. عند العرض اللانهائي، تطوّر المعاملات ODE حتميّ (NTK، 11.7-11) $\Longrightarrow$ تجمّد التدريب. ■

- **نتيجة:** تحديد حتمي.
- **الربط بالذكاء الاصطناعي:** «لماذا الشبكات العميقة تتعلّم كنواة» = نظام ODE عند العرض اللانهائي.

خيط الفصل

١. **ODE (12.2):** $\dot{x} = f$ مع شرط بداية؛ الوجود/الوحيدة بـ Lipschitz — لغة «التطوّر الزمني».

٢. **الطرق العددية (12.3):** أويلر (خلف (!GD وRK4 تُقطّع الزمن؛ خطأ $O(h)$ لأويلر.

٣. **التحليل الكيفي (12.4):** النقاط الثابتة والاستقرار عبر J_f — يفسّر تقارب/علوق التدريب.

٤. **PDE (12.5):** الحرارية = انتشار = أساس blur و dffiusion (نواة غاوسية).

٥. **النظم والتعلّم (12.6):** $\dot{\theta} = -\nabla L$ تدفّق تدرّجي؛ الخسارة ليانوف تتناقص.

٦. **التطبيقات (12.7):** ODE Neural و Dffiusion/SDE — التوليد الحديث = حلّ SDE عكسي بقيادة السكور.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
GD = أويلر (3.12)	كلّ نظريات التحسين (الجزء 4)
ليانوف (6.12)	تقارب التعلّم، الاستقرار
السكور/SDE (7.12)	dffiusion، بايز، أخذ العيّنات (الجزء 3، 7)
نقطة ثابتة (4.12)	توازنات الشبكات، NTK
لابلاسيان/PDE (5.12)	معالجة الإشارات، الرؤية
ODE Neural (7.12)	نماذج التدفّق، التوليد

١. حلّ $\dot{x} = 3x$، $x(0) = 2$ وحدّد سلوك $t \to \infty$.

٢. أثبت بيكار-ليندلوف لـ $\dot{x} = f(x)$ Lipschitz محليّاً.

٣. لـ $\dot{x} = x^{1/3}$، $x(0) = 0$، أعطِ حلّين مختلفين (فقدان الوحيدة).

٤. خطوة أويلر واحدة لـ $\dot{x} = -2x$، $x(0) = 1$، $h = 0.1$ (قارن بـ $e^{-0.2}$).

٥. اشتقق شرط الاستقرار $|1 + h\lambda| < 1$ لأويلر على $\dot{x} = \lambda x$.

٦. لـ لوجستيك، صنّف النقاط $0, K$ باليعقوبية.

٧. أثبت أنّ $V(x) = x^2$ ليانوف لـ $\dot{x} = -x$.

٨. حلّ $\ddot{x} = -\omega^2 x$ وحدّد أنّه مركز (لا جاذب).

٩. اكتب معادلة الحرارة الأسّية (نواة غاوسية) وفسّر انتشارها.

١٠. بفصل المتغيرات، أثبت أنّ أوضاع الحرارية تضمحلّ كـ $e^{-\alpha k^2 t}$.

١١. أثبت $dL/dt = -\|\nabla L\|^2$ لتدفّق التدرّج.

١٢. اربط GD المنفصل بـ أويلر (اكتب الصيغتين).

١٣. لـ SGD عبر SDE: $\dot{\theta} = -\nabla L + \sigma\xi$، ناقش دور الضجيج في الهروب من السرج.

١٤. اكتب SDE أمامي VP وعكسي (صيغة أندرسون) مع السكور.

١٥. اشتقّ Tweedie $\mathbb{E}[x_0|x_t] = x_t + \beta_t \nabla \log p_t(x_t)$ (اربط بـ ch11).

١٦. صفّ طريقة المُلحَقة (adjoint) لـ ODE Neural ولماذا ذاكرتها $O(1)$.

١٧. عرّف حوض الجذب واربطه بحساسية التهيئة في التدريب.

١٨. لـ $A = \text{diag}(-1, -2)$، حدّد نوع النقطة الثابتة للنظام $\dot{x} = Ax$.

١٩. اشرح لماذا «الحرارية العكسية مطروحة سيّئة» (مبدأ الأقصى) وعلاقتها بـ denoising.

٢٠. تحدٍّ تركيبي: «لماذا التدريب يتقارب؟» — اجمع: أويلر=GD لمستمرّ (3.12)، الخسارة ليانوف (6.12)، والنقطة الثابتة مُثلّث محلّي مستقرّ بـ $H \succ 0$ (4.4,11.12) — واذكر متى يفشل (سرج، تكيّف سيّئ من 6.11).

- **ODE (1.12):** $\dot{x} = f(t,x)$ مع $x(t_0) = x_0$؛ الوجود/الوحيدة بـ Lipschitz (بيكار-ليندلوف).
- **الطرق (2.12):** أويلر $x_{n+1} = x_n + h\dot{x}_n$ (عالمي $O(h)$)؛ RK4 أعلى رتبة.
- **الاستقرار (3.12):** $\dot{\xi} = \nabla f(x^*)\xi$؛ $\operatorname{Re}\lambda < 0 \Rightarrow$ مستقرّ.
- **PDE (4.12):** الحرارية $\partial_t u = \alpha \nabla^2 u$، حلّها أسّ غاوسي؛ مبدأ الأقصى.
- **تدفّق التدرّج (5.12):** $\dot{\theta} = -\nabla L$، $dL/dt = -\|\nabla L\|^2$ (ليانوف)؛ GD = أويلر له.
- **التطبيقات (6.12):** Neural ODE $\dot{z} = f_\theta(z,t)$؛ VP-SDE أمامي/عكسي بقيادة السكور $\nabla \log p$ (أساس dffiusion).

الرمز	المعنى	أين عُرّف
$\dot{x}$	المشتقّة الزمنية	(1.12)
h	حجم الخطوة	(2.12)
J_f	يعقوبية الحقل	(3.12)
$\nabla^2 u$	اللابلاسيان	(4.12)
$L(\theta)$	الخسارة (ليانوف)	(5.12)
$\nabla \log p$	السكور	(6.12)

١. S. Strogatz, (2018). *Nonlinear Chaos and Dynamics*, 2nd ed., CRC Press — التحليل الكيفي والنقاط الثابتة.

٢. R. DiPrima, & W. Boyce, (2017). *Elementary Differential Equations*, 11th ed., Wiley — ODE وحلولها.

٣. R. LeVeque, (2007). *Finite Difference Methods for ODE/PDE*, SIAM — الطرق العددية والاستقرار.

٤. L. Evans, (2010). *Partial Differential Equations*, 2nd ed., AMS — الحرارية/الموجية/اللابلاسيان.

٥. B. Anderson, (1982). *Reverse-time diffusion equation models* (stochastic processes) — أساس SDE العكسي.

٦. R. Chen, et al. (2018). *Neural Ordinary Differential Equations* (NeurIPS) — تدفّق عصبي مستمرّ.

٧. S. Ermon, & Y. Song, (2019); J. Ho, et al. (2020), dffiusion/SDE — DDPM والسكور $(\nabla \log p)$.

٨. L. Bottou, (2010). *Large-Scale Machine Learning with SGD* — GD كديناميكا عشوائية؛ يربط بـ 6.12.

٩. N. Qian, (1999); I. Sutskever, et al. (2013) — الزخم/نيستيروف كـ ODE من الدرجة الثانية.

القسم III

الاحتمالات والإحصاء

نبذة عن هذا الجزء

البيانات التي يتعلّم منها الذكاء الاصطناعي لا تُعطى؛ تُرسَم من توزيعٍ لا نعرفه. هذا الجزء يبني الرسميّة الكاملة للتعامل مع العشوائية: نبدأ بـ**فضاءات الاحتمال** حيث الاحتمال قياسٌ رياضي خالص، ثم **المتغيّرات العشوائية وتوزيعاتها** بوصفها المحرّكات التي تُولّد البيانات، و**التوقّعات والتباينات** بوصفها العدسات التي نرى بها الخطأ. ثم نصل إلى قلب الاستدلال الحديث: **الشرطيّة وشبكات بايز** التي تُحدّث المعتقد بالدليل، و**مترابحات التركيز** التي تشرح لماذا «تتجمّع» المتوسطات وتسمح لنا بالمراهنة عليها، فـ**الاستدلال الإحصائي** بطرائقه القصوى MLE وMAP وخوارزمية EM، ونختم بـ**العمليات العشوائية** وسلاسل الزمن حيث الزمن نفسه يدخل المعادلة. الجزءان السادس والسابع سيقفان على كتفي هذا الجزء مباشرة: كلّ نظرية تعلّم هي في العمق جملة احتماليّة. **فصول الجزء:** فضاءات الاحتمال · المتغيّرات العشوائية والتوزيعات · التوقّع والتباين والمصفوفات الموجبة · الشرطيّة وبايز والحقول العشوائية · مترابحات التركيز · الاستدلال الإحصائي MLE/EM · العمليات العشوائية وسلاسل الزمن.

فصول هذا الجزء

- **الفصل 13.** فضاءات الاحتمال وبُنى القياس
- **الفصل 14.** المتغيرات العشوائية والتوزيعات القياسية
- **الفصل 15.** المتوقّع، التباين، والمصفوفات الموجبة
- **الفصل 16.** الاحتمال الشرطي المتقدّم، بايز، والحقول العشوائية
- **الفصل 17.** مترابحات التركيز (Concentration Inequalities)
- **الفصل 18.** الإستدلال الإحصائي وتقدير المعلمات (MLE) / MAP)
- **الفصل 19.** السلاسل الزمنية والعمليات العشوائية

فضاءات الاحتمال وبُنى القياس

الهدف من الفصل

أوّل فصول الجزء الثالث (الاحتمالات والإحصاء). أنهينا الأسس (1–6) والتفاضل/التكامل (7–12)، وبالأخص بنينا نظرية القياس وتكامل ليبيسغ–ستيلتjes (الفصل 10) والأنظمة العشوائية (الفصل 12). الآن نكتشف أنّ «الاحتمال هو قياس بـ $P(\Omega) = 1$»: كلّ ما في هذا الفصل هو حالة خاصّة من الفصل 10. هذا الجسر يُحوّل «المخاطرة المتوقّعة» و«التوزيعات» و«بايز» من بديهيات إلى رياضيات صارمة.

أربعة دوافع تجعل هذا الفصل أساس الذكاء الاصطناعي الاحتمالي:

١. **الاحتمال = قياس خاصّ:** $(\Omega, \mathcal{F}, \mathbb{P})$ هو بالضبط $(\Omega, \mathcal{F}, \mu)$ من الفصل 10 مع $\mathbb{P}(\Omega) = 1$. كلّ نظريات القياس (السيغما-جبرا، القابلية العدّية، التكامل) تُعاد استخدامها.

٢. **المتغيّر العشوائي = دالة قياسية:** $X : \Omega \to \mathbb{R}$ تقابل «الدالة القياسية» (الفصل 4.10)؛ وتوزيعه هو «قياس مدفوع» (pusfhorward).

٣. **التوقّع = تكامل ليبيسغ–ستيلتjes:** $\mathbb{E}[X] = \int x \, dF(x)$ هو بالضبط ما بنيناه في (7.10) — لا شيء جديد، فقط لغة الاحتمال.

٤. **التقارب الاحتمالي = قاعدة التعلّم:** SGD (الفصل 6.12) يتقارب «بالاحتمال»؛ وفهم أنماط التقارب يسبق نظريات التعميم (الجزء السادس).

خريطة الفصل

القسم	الموضوع	الأداة المركزية
2.13	فضاء الاحتمال الكولموغروفي	$(\Omega, \mathcal{F}, \mathbb{P})$
3.13	المتغيّرات العشوائية (قياسية)	$X : \Omega \to \mathbb{R}$
4.13	التوزيعات: CDF/PMF/PDF	$F(x) = \mathbb{P}(X \le x)$
5.13	الاحتمال الشرطي والاستقلال	$\mathbb{P}(A \mid B)$ وبايز
6.13	التوقّع كتكامل ليبيسغ–ستيلتjes	$\mathbb{E}[X] = \int x \, dF$
7.13	أنماط التقارب الاحتمالي	dist / L^p / prob / a.s.

التعريف

dir="ltr"> <div

triple a is space probability A **Kolmogorov). space, (Probability 1.2.13 Definition**

where $(\Omega, \mathcal{F}, \mathbb{P})$

- space; sample the is Ω
- events; of -**algebra**σ a is $\mathcal{F} \subseteq 2^{\Omega}$

additivity: countable and $\mathbb{P}(\Omega) = 1$ with **measure probability** a is $\mathbb{P} : \mathcal{F} \to [0, 1]$ •

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n) \quad \text{disjoint for} A_n \in \mathcal{F}. \tag{1.13}$$

dir="ltr"> <div
consequences: Immediate **.axioms Kolmogorov** the are requirements three These
inclusion–exclusion. and ,$\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$,$\mathbb{P}(\varnothing) = 0$

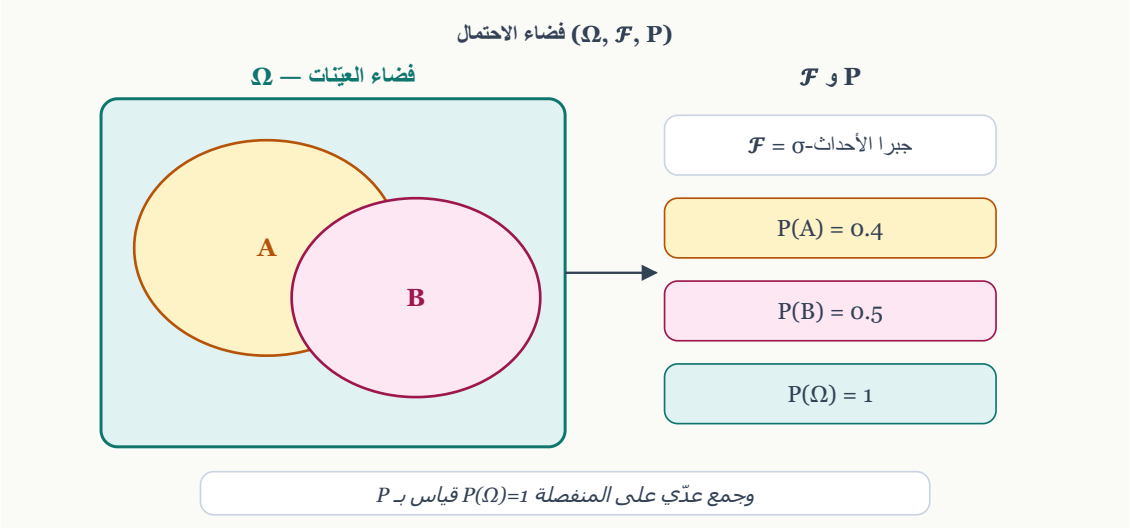
النظرية 1.2.13 (الاستمرارية): $\mathbb{P}$ تتمتّع باستمرارية من الأسفل/الأعلى تماماً كـ μ في (1.2.10) — لأنّها قياس.

جدول الرموز

الرمز	الاسم	المعنى
Ω	فضاء العيّنات	كلّ النواتج الممكنة
$\mathcal{F}$	σ-جبرا الأحداث	ما «يُحتمل» قياسه
$\mathbb{P}$	القياس الاحتمالي	$\mathbb{P}(\Omega) = 1$

رسم توضيحي

<figure> الشكل<figcaption> 1.13: $(\Omega, \mathcal{F}, \mathbb{P})$ — Ω يحوي النواتج، $\mathcal{F}$ مجموعة الأحداث القابلة للقياس، و



شكل ١٠١٣: *
فضاء الاحتمال Ω مع أحداث ونِسَب

$\mathbb{P}$ يوزّع الكتلة 1 على الأحداث. لاحظ أنّه نفس بنية $(\Omega, \mathcal{F}, \mu)$ من الفصل 10 بقياس مجموعه 1.</figcaption>
</figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«كل مجموعة فرعية حدث»	قد لا تكون قابلة للقياس	اقتصر على $\mathcal{F}$
نسيان $\mathbb{P}(\Omega)=1$	يميّز الاحتمال عن القياس	هو شرط كولموغروف
خلط المنفصل بالعدّي	القابلية العدّية للمتناهية	استخدم الجمع العدّي
اعتبار $P(A\cup B)=P(A)+P(B)$ دائماً	يحتاج منفصلة	اطرح التقاطع

أمثلة محلولة على فضاء الاحتمال (15 مثالاً)

مثال (13.2-1).

- **المعطيات:** رمي مئة وجه: $\Omega=\{1,\dots,6\}$، $\mathcal{F}=2^{\Omega}$.
- **المطلوب:** عرّف فضاء احتمال منتظم.
- **الحل:**

١. $\mathbb{P}(\{i\})=1/6$ لكل i، يمتدّ بالجمع العدّي. ■

- **النتيجة:** فضاء منفصل منتظم.
- **الربط بالذكاء الاصطناعي:** «توزيع فئوي منتظم» = baseline لأيّ مُصنّف.

مثال (13.2-2).

- **المعطيات:** لخّص محاور كولموغروف.
- **المطلوب:** اذكرها.
- **الحل:**

١. (1) $\mathbb{P}(\Omega)=1$؛ (2) $\mathbb{P}(A)\geq 0$؛ (3) جمع عدّي للمنفصلة. ■

- **النتيجة:** ثلاثة محاور.
- **الربط بالذكاء الاصطناعي:** «احتمال كقياس» يضمن اتساق كلّ حسابات التوزيع.

مثال (13.2-3).

- **المعطيات:** حدث A.
- **المطلوب:** أثبت $\mathbb{P}(A^c)=1-\mathbb{P}(A)$.
- **الحل:**

١. $\Omega=A\cup A^c$ منفصلتان $\Rightarrow 1=\mathbb{P}(A)+\mathbb{P}(A^c)$. ■

- **النتيجة:** قاعدة المتمّم.
- **الربط بالذكاء الاصطناعي:** «1 − احتمال النجاح = فشل» — أساس كلّ المقاييس.

مثال (2.13-4).

- **المعطيات:** حدثان A, B.
- **المطلوب:** $\mathbb{P}(A \cup B)$.
- **الحل:**

١. $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$. ■

- **النتيجة:** شمول واستبعاد احتمالي.
- **الربط بالذكاء الاصطناعي:** «احتمال اتحاد الصنفين» = قاعدة تجميع في التصنيف المتعدّد.

مثال (2.13-5).

- **المعطيات:** أحداث منفصلة $A_1, \dots, A_n$.
- **المطلوب:** هل الجمع المنتهي مضمون؟
- **الحل:**

١. نعم — نتيجة القابلية العدّية (خذ الباقي فارغاً). ■

- **النتيجة:** جمع منتهٍ.
- **الربط بالذكاء الاصطناعي:** «مجموع احتمالات الفئات = 1» — قيد softmax.

مثال (2.13-6).

- **المعطيات:** $\mathcal{F}$ سيغما-جبرا (من 2.10).
- **المطلوب:** لماذا نحتاجها لا كلّ 2^Ω؟
- **الحل:**

١. السيغما-جبرا تغلق تحت المتمّم والاتحاد العدّي — شرط لوجود $\mathbb{P}$ جيّد. ■

- **النتيجة:** بُنية ضرورية.
- **الربط بالذكاء الاصطناعي:** «ما يُقاس = ما يُعلَّم» — الحدث القابل للقياس فقط المُعرَّف احتماله.

مثال (2.13-7).

- **المعطيات:** $\Omega = [0,1]$، $\mathbb{P} =$ قياس ليبيسغ m.
- **المطلوب:** هل هذا فضاء احتمال؟
- **الحل:**

١. $m([0,1]) = 1$ $\Longrightarrow$ نعم، بشرط قصره على $[0,1]$. ■

- **النتيجة:** احتمال مستمرّ.
- **الربط بالذكاء الاصطناعي:** «توزيع مستمرّ على [0,1]» — أساس ضجيج موحّد في GAN/dffiusion.

مثال (13.2-8).

- **المعطيات:** حدث مستحيل $\varnothing$.
- **المطلوب:** $\mathbb{P}(\varnothing)$.
- **الحل:**

١. $\mathbb{P}(\varnothing) = 1 - \mathbb{P}(\Omega) = 0$. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «حدث مستحيل باحتمال 0» — لكن العكس ليس دائماً (نقطة بقيمة 0 في المستمرّ).

مثال (13.2-9).

- **المعطيات:** $A \subset B$.
- **المطلوب:** علاقة الاحتمالات.
- **الحل:**

١. $\mathbb{P}(A) \le \mathbb{P}(B)$ (أحاديّة التوتّر كـ μ). ■

- **النتيجة:** احتمال رتيب.
- **الربط بالذكاء الاصطناعي:** «احتمال مجموعة فرعية $\le$ الكلّي» — أساس الحدود العلوية للخطأ.

مثال (13.2-10).

- **المعطيات:** $A_n \uparrow A$.
- **المطلوب:** $\lim \mathbb{P}(A_n)$.
- **الحل:**

١. الاستمرارية من الأسفل (من 1.2.10): $\mathbb{P}(A_n) \to \mathbb{P}(A)$. ■

- **النتيجة:** تقارب القياس.
- **الربط بالذكاء الاصطناعي:** «احتمال الحدّ التراكمي» يتقارب — يظهر في تقارب التوزيعات.

مثال (13.2-11).

- **المعطيات:** حدّ بويل (union bound) $\mathbb{P}(\cup A_n) \le \sum \mathbb{P}(A_n)$.
- **المطلوب:** اشتقّه من القابلية العدّية.
- **الحل:**

١. بفصل الأحداث المتنافية $\mathbb{P}(\cup A_n) = \mathbb{P}(\cup (A_n \setminus \cup_{k<n} A_k)) \le \sum \mathbb{P}(A_n)$. ■

- **النتيجة:** متراجحة أساسية.
- **الربط بالذكاء الاصطناعي:** «احتمال خطأ واحد على الأقلّ» ≤ مجموع الاحتمالات — union bound في التعلّم (ch31).

مثال (13.2-12).

- **المعطيات:** لماذا $\mathbb{P}(\Omega) = 1$ لا $\mathbb{P}(\Omega) = \infty$؟
- **الحل:**

١. لتطبيع «اليقين» إلى 1 بدل كتلة مطلقة؛ يسهّل المقارنة بين التوزيعات. ■

- **النتيجة:** تطبيع.
- **الربط بالذكاء الاصطناعي:** «تطبيع» softmax/exp = نفس فكرة $\mathbb{P}(\Omega) = 1$.

مثال (13.2-13).

- **المعطيات:** مجموعة غير قابلة للقياس (فيتالي).
- **المطلوب:** هل يمكن احتمالها؟
- **الحل:**

١. لا — لذلك $\mathcal{F}$ لا 2^Ω؛ نتجنّبها بـ بوريل. ■

- **النتيجة:** قياس على بوريل.
- **الربط بالذكاء الاصطناعي:** «نتعامل مع بوريل فقط» = افتراض قياسي في كلّ نموذج احتمالي.

مثال (13.2-14).

- **المعطيات:** فضاء منفصل نهائي بأوزان $p_i \ge 0$، $\sum p_i = 1$.

- **المطلوب:** اربطه بـ (15-2.10).
- **الحل:**

١. هو نفس قياس الاحتمال المنفصل من الفصل 10. ■

- **النتيجة:** حالة خاصّة.
- **الربط بالذكاء الاصطناعي:** «توزيع فئوي = أوزان «softmax — نقطة التقاء 2.10 و13.

مثال (15-2.13).

- **المعطيات:** $\mathbb{P}$ كقياس.
- **المطلوب:** أيّ نظريات الفصل 10 تنتقل؟
- **الحل:**

١. كلّ نظريات القياس (سيغما-جبرا، استمرارية، تكامل) تنتقل حرفيًّا. ■

- **النتيجة:** إعادة استخدام كاملة.
- **الربط بالذكاء الاصطناعي:** «بناء احتمالي على قياس» = ترشيد كلّ إحصاء لاحق.

التعريف

dir="ltr"> <div

function **measurable** a is variable random A **variable). (Random 1.3.13 Definition**
is (pusfhorward) **distribution** Its .x all for $\{\omega : X(\omega) \le x\} \in \mathcal{F}$ i.e. ,$X : (\Omega, \mathcal{F}) \to (\mathbb{R}, \mathcal{B})$

$$\mathbb{P}_X(B) = \mathbb{P}(X \in B) = \mathbb{P}\big(X^{-1}(B)\big), \qquad B \in \mathcal{B}.$$

$$\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B)). \tag{2.13}$$

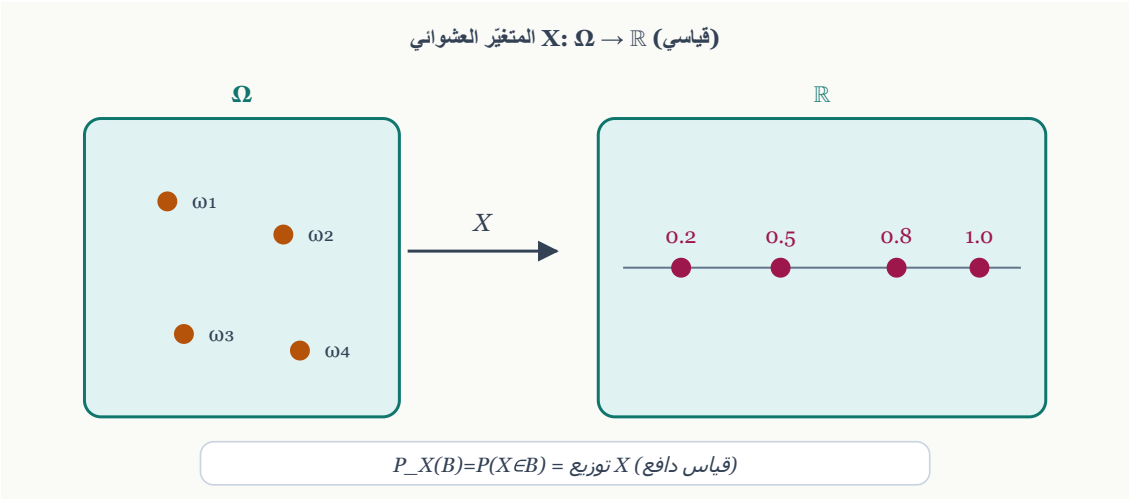
dir="ltr"> <div

random A .1.7.10 / 1.4.10 Definition from μ_f measure pusfhorward the exactly is This
.$X : \Omega \to \mathbb{R}^d$ is vector

النظرية 1.3.13 (قياسيّة التحويل): إن كانت g بوريل-قياسية فـ $g(X)$ متغيّر عشوائي؛ و $\mathbb{P}_{g(X)}(B) = \mathbb{P}_X(g^{-1}(B))$.

جدول الرموز

الرمز	الاسم	المعنى
X	متغيّر عشوائي	دالة قياسية $\Omega \to \mathbb{R}$
$\mathbb{P}_X$	توزيع X	قياس مدفوع على $\mathbb{R}$
$X^{-1}(B)$	الصورة العكسية	«الحدث $X \in B$»



شكل ٢.١٣: *
المتغيّر العشوائي كدالة قياسية وقياس مدفوع

رسم توضيحي

<figure> الشكل<figcaption>2.13: X تربط كلّ نتيجة ω_i بقيمة عددية؛ توزيعها $\mathbb{P}_X$ هو «قياس مدفوع» على الخط الحقيقي (نقاط بأوزان). يقابل الدالة القياسية والمقياس المرافق من الفصل 10.</figcaption></figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الخلط بين X (دالة) و x (قيمة)	X عشوائية، x عدد	اكتب الحدث $\{X \le x\}$
نسيان شرط القياس	التكامل غير معرّف	تحقّق $\{X \le x\} \in \mathcal{F}$
اعتبار كل دالة متغيّر عشوائي	يجب أن تكون قياسية	افحص الصورة العكسية
خلط التوزيع بالعيّنة	$\mathbb{P}_X$ نظريّ، العيّنات ملموسة	الأولى حدّ، الثانية بيانات

أمثلة محلولة على المتغيّرات العشوائية (15 مثالاً)

مثال (3.13-1).

- **المعطيات:** $X : \Omega \to \mathbb{R}$، $\{X \le x\} \in \mathcal{F}$.
- **المطلوب:** عرّف المتغيّر العشوائي.
- **الحل:**

١. هو دالة قياسية ببوريل (كـ 10.4.1). ■

- **النتيجة:** يقابل الدالة القياسية.
- **الربط بالذكاء الاصطناعي:** «مخرج الشبكة = متغيّر عشوائي» — يضمن تعريف احتماله.

مثال (3.13-2).

- **المعطيات:** $X = \mathbf{1}_A$.
- **المطلوب:** هل قياسية؟
- **الحل:**

١. $\{X \le x\}$ هي $\emptyset, \Omega, A^c, \Omega$ حسب x — كلها في $\mathcal{F}$. ■

- **النتيجة:** مؤشّر حدث = متغيّر عشوائي.
- **الربط بالذكاء الاصطناعي:** «دالة التنشيط العتبة» = متغيّر مؤشّر — احتمالها معرّف.

مثال (3.13-3).

- **المعطيات:** $X = \sum a_i \mathbf{1}_{A_i}$ (بسيطة).
- **المطلوب:** وزّعها.
- **الحل:**

١. $\mathbb{P}_X$ كتل a_i بأوزان $\mathbb{P}(A_i)$. ■

- **النتيجة:** توزيع منفصل.
- **الربط بالذكاء الاصطناعي:** «هيستوغرام» = متغيّر بسيط — تقريب أيّ توزيع.

مثال (3.13-4).

- **المعطيات:** X منفصلة بقيم $\{x_i\}$.
- **المطلوب:** توزيعها.
- **الحل:**

١. $\mathbb{P}_X = \sum p_i \delta_{x_i}$ (كتل نقطية). ■

- **النتيجة:** قياس نقطي.
- **الربط بالذكاء الاصطناعي:** «توزيع فئوي» = مجموع دلتات — softmax النهائي.

مثال (3.13-5).

- **المعطيات:** X مستمرّة بكثافة f.

- **المطلوب:** $\mathbb{P}_X$.
- **الحل:**
١. $\mathbb{P}_X(B) = \int_B f(x)dx$ (قياس ليبيسغ بكثافة). ■
- **النتيجة:** قياس بكثافة.
- **الربط بالذكاء الاصطناعي:** «توزيع مستمرّ» = كثافة على $\mathbb{R}^d$ — نموذج التوليد.

مثال (3.13-6).

- **المعطيات:** g بوريل-قياسية، $Y = g(X)$.
- **المطلوب:** هل Y متغيّر عشوائي؟
- **الحل:**
١. تركيب قياسي بقياسي (3.4.10) $\Longrightarrow$ قياسي. ■
- **النتيجة:** نعم.
- **الربط بالذكاء الاصطناعي:** «تطبيق أيّ تنشيط» يحافظ القياس — مخرجات الشبكة كلها قياسية.

مثال (3.13-7).

- **المعطيات:** X, Y متغيّران عشوائيان.
- **المطلوب:** هل $X + Y$ قياسية؟
- **الحل:**
١. مجموع قياسي (14.4.10) $\Longrightarrow$ قياسي. ■
- **النتيجة:** نعم.
- **الربط بالذكاء الاصطناعي:** «جمع الميزات/الطبقات» ينتج متغيّراً معرّفاً.

مثال (3.13-8).

- **المعطيات:** عرّف $\mathbb{P}_X(B) = \mathbb{P}(X \in B)$.
- **المطلوب:** تحقّق أنّها قياس.
- **الحل:**
١. X^{-1} تحفظ اتحادات/متمّمات $\Longrightarrow$ $\mathbb{P}_X$ قياس على $\mathcal{B}$. ■
- **النتيجة:** توزيع = قياس مدفوع.
- **الربط بالذكاء الاصطناعي:** «توزيع المخرجات» يحسبه بالضبط — أساس التقييم.

مثال (3.13-9).

- **المعطيات:** X يوحّد القيم.
- **المطلوب:** ما $\mathbb{P}_X$؟
- **الحل:**

١. $\mathbb{P}_X$ = توزيع القيم على $\mathbb{R}$ (نفس توزيع X). ■

- **النتيجة:** قياس مدفوع بالهويّة.
- **الربط بالذكاء الاصطناعي:** «تطبيع المخرجات» = إعادة توزيع على نطاق معياري.

مثال (3.13-10).

- **المعطيات:** $X \sim \text{Bernoulli}(p)$ من رمي.
- **المطلوب:** حدد X وتوزيعها.
- **الحل:**

١. $X(\omega) = 1$ للنجاح، 0 لغيره؛ $\mathbb{P}_X(\{1\}) = p,\ \{0\} = 1 - p$. ■

- **النتيجة:** توزيع برنولي.
- **الربط بالذكاء الاصطناعي:** «تصنيف ثنائي» = برنولي — الاحتمال = p.

مثال (3.13-11).

- **المعطيات:** $X(\omega) = \omega$ على $\Omega = [0,1]$ بـ ليبيسغ.
- **المطلوب:** ما توزيعها؟
- **الحل:**

١. $\mathbb{P}_X([a,b]) = b - a \implies$ موحّد على $[0,1]$. ■

- **النتيجة:** $\text{Unfiorm}(0,1)$.
- **الربط بالذكاء الاصطناعي:** «عيّنة موحّدة» = أساس كلّ توليد عشوائي (تحويل عكسي).

مثال (3.13-12).

- **المعطيات:** $\{X \le x\} \in \mathcal{F}$.

- **المطلوب:** لماذا يكفي لكلّ x؟
- **الحل:**
١. الفترات $(-\infty, x]$ تولّد بوريل (14-2.10) $\Longrightarrow$ كلّ بوريل قياسي. ■
- **النتيجة:** شرط أدنى كافٍ.
- **الربط بالذكاء الاصطناعي:** «لتعرّف توزيعاً يكفي «CDF — يبسّط كلّ تمثيل.

مثال (13-3.13).

- **المعطيات:** متغيّر عشوائي متّجه $X : \Omega \to \mathbb{R}^d$.
- **المطلوب:** التوزيع المشترك.
- **الحل:**
١. $\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B))$ على $\mathcal{B}(\mathbb{R}^d)$. ■
- **النتيجة:** قياس على $\mathbb{R}^d$.
- **الربط بالذكاء الاصطناعي:** «ميزات متعدّدة الأبعاد» = متغيّر متّجه — أساس بيانات التدريب.

مثال (14-3.13).

- **المعطيات:** نفس X مع $\mathcal{F}$ مختلفة.
- **المطلوب:** هل تبقى قياسية؟
- **الحل:**
١. لا — إن كانت $\{X \le x\} \notin \mathcal{F}$ الجديدة فلا. ■
- **النتيجة:** القياس يعتمد على $\mathcal{F}$.
- **الربط بالذكاء الاصطناعي:** «مستوى المعلومات» يحدّد ما نستطيع قياس احتماله.

مثال (15-3.13).

- **المعطيات:** لماذا نشترط القياس؟
- **المطلوب:** اربط بالتكامل.
- **الحل:**
١. بلا قياس، $\mathbb{E}[X] = \int X \, d\mathbb{P}$ غير معرّف. ■
- **النتيجة:** شرط لوجود التوقّع.
- **الربط بالذكاء الاصطناعي:** «التوقّع = تكامل» يتطلّب قياس المتغيّر (6.13).

التعريف

dir="ltr"> <div
is **function distribution cumulative** The **PDF). / PMF / (CDF 1.4.13 Definition**

$$F_X(x) = \mathbb{P}(X \le x).$$

satisfies PDFf_X :X continuous absolutely an For . PMF$p_X(x) = \mathbb{P}(X = x)$:X discrete a For a.e.). $f_X = F_X'$ (so $F_X(x) = \int_{-\infty}^{x} f_X(t)\,dt$

$$F_X(x) = \mathbb{P}(X \le x), \qquad \mathbb{P}(a < X \le b) = F_X(b) - F_X(a). \tag{3.13}$$

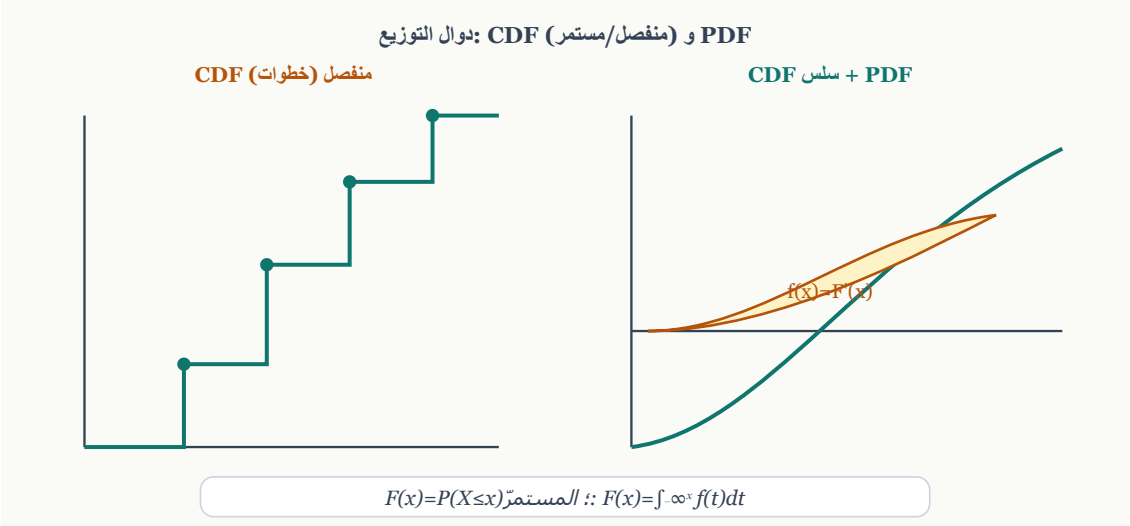
النظرية 1.4.13 (خصائص CDF): F غير تنازليّة، يمين-مستمرة، $\lim_{x\to-\infty} F = 0$، $\lim_{x\to\infty} F = 1$. و F تحدّد التوزيع uniquely.

جدول الرموز

الرمز	الاسم	المعنى
F_X	دالة التوزيع التراكمي	$\mathbb{P}(X \le x)$
p_X	كتلة الاحتمال	للمنفصل
f_X	كثافة الاحتمال	للسلس (مشتقّة F)

رسم توضيحي

<figure> الشكل<figcaption> 3.13: يساراً CDF منفصل (خطوات عند قيم X)؛ يميناً CDF سلس مع كثافته



شكل ٣.١٣: *
CDF منفصل مقابل سلس و PDF

$f = F'$ تحته. كلاهما يبدأ من 0 وينتهي عند 1.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
استخدام PDF للمنفصل	المنفصل بلا كثافة	استخدم PMF
نسيان F يمين-مستمرة	شرط تعريف	$F(x) = \mathbb{P}(X \le x)$ بـ $\le$
اعتبار $f(x)$ احتمالاً	f كثافة لا P	P يحتاج تكاملاً على فترة
خلط $P(X = x)$ بـ $f(x)dx$	الأول نقطة، الثاني عنصر	$P(X = x) = 0$ للمستمرّ

أمثلة محلولة على التوزيعات (15 مثالاً)

مثال (13.4-1).

- **المعطيات:** خصائص F_X.
- **المطلوب:** اذكرها.
- **الحل:**

١. غير تنازليّة، يمين-مستمرة، حدود 0 و1. ■

- **النتيجة:** ثلاث خصائص.
- **الربط بالذكاء الاصطناعي:** CDF» = دالة احتمال تراكمي» — مخرج كلّ تقدير توزيع.

مثال (13.4-2).

- **المعطيات:** F_X معلومة.
- **المطلوب:** هل تحدّد التوزيع؟
- **الحل:**

١. نعم — $\mathbb{P}_X$ يُستنتج من F_X بشكل وحيد. ■

- **النتيجة:** CDF كافية.
- **الربط بالذكاء الاصطناعي:** «لمقارنة توزيعين يكفي مقارنة «CDF — أساس اختبارات التوزيع.

مثال (13.4-3).

- **المعطيات:** X منفصلة بـ p_X.
- **المطلوب:** $F_X(x)$.
- **الحل:**

١. $F_X(x) = \sum_{t \le x} p_X(t)$ (مجموع تراكمي). ■

- **النتيجة:** خطوات.
- **الربط بالذكاء الاصطناعي:** CDF» تراكمي للفئات» = مجموع softmax تراكمي.

مثال (13.4-4).

- **المعطيات:** X سلس بكثافة f_X.
- **المطلوب:** العلاقة مع F_X.
- **الحل:**

١. $F_X(x) = \int_{-\infty}^{x} f_X(t)\,dt$، و $f_X = F_X'$ أينما كانت قابلة للاشتقاق. ■

- **النتيجة:** تكامل/مشتقّة.
- **الربط بالذكاء الاصطناعي:** «الكثافة = مشتقّة CDF» — يربط score بـ f'/f. (ch12.7)

مثال (13.4-5).

- **المعطيات:** f_X كثافة.
- **المطلوب:** تحقّق $\int f_X = 1$.
- **الحل:**

١. $\int_{-\infty}^{\infty} f_X = F_X(\infty) - F_X(-\infty) = 1 - 0 = 1$. ■

- **النتيجة:** تطبيع الكثافة.
- **الربط بالذكاء الاصطناعي:** «تطبيع الكثافة» = شرط صحّة أيّ نموذج توليدي.

مثال (13.4-6).

- **المعطيات:** $\mathbb{P}(a < X \le b)$.
- **المطلوب:** عبّره بـ CDF.
- **الحل:**

١. $F_X(b) - F_X(a)$. ■

- **النتيجة:** فرق CDF.
- **الربط بالذكاء الاصطناعي:** «احتمال فترة» = فرق CDF — أساس فترات الثقة.

مثال (13.4-7).

- **المعطيات:** $X \sim \text{Bernoulli}(p)$.

- **المطلوب:** PMF و CDF.
- **الحل:**

١. $p_X(1) = p,\ p_X(0) = 1 - p$؛ $F(x) = 0\ (x < 0),\ 1 - p\ (0 \le x < 1),\ 1\ (x \ge 1)$. ■

- **النتيجة:** توزيع خطوتين.
- **الربط بالذكاء الاصطناعي:** «احتمال الإيجاب» = قيمة CDF عند 1.

مثال (13.4-8).

- **المعطيات:** $X \sim \text{Unfiorm}[a, b]$.
- **المطلوب:** الكثافة و CDF.
- **الحل:**

١. $f_X = 1/(b - a)$ على $[a, b]$؛ $F_X = (x - a)/(b - a)$ هناك. ■

- **النتيجة:** مستطيلة.
- **الربط بالذكاء الاصطناعي:** «توزيع موحّد» = مصدر كلّ التوليد (inverse CDF).

مثال (13.4-9).

- **المعطيات:** اربط CDF بـ ليبيسغ–ستيلتjes (7.10).
- **المطلوب:** الصيغة.
- **الحل:**

١. $\mathbb{P}_X$ هو μ_F من (1.7.10)؛ لذا CDF هي بالضبط دالة كثافة التوزيع هناك. ■

- **النتيجة:** تطابق تامّ.
- **الربط بالذكاء الاصطناعي:** «CDF» = Stieltjes measure» يوحّد الفصلين 10 و13.

مثال (13.4-10).

- **المعطيات:** $X \sim \mathcal{N}(0, 1)$.
- **المطلوب:** لماذا لا صيغة مغلقة لـ F؟
- **الحل:**

١. تكامل $e^{-t^2/2}$ بلا أصل أوليّ ابتدائيّ $\Longrightarrow$ نعتمد الجداول/التقريب. ■

- **النتيجة:** تعتمد على erf.
- **الربط بالذكاء الاصطناعي:** «الغاوسي بلا CDF مغلقة» — يُقدَّر عددياً دوماً في الممارسة.

مثال (11-4.13).

- **المعطيات:** $X \sim \text{Exp}(\lambda)$.
- **المطلوب:** الكثافة و CDF.
- **الحل:**

١. $f_X = \lambda e^{-\lambda x}$ $(x \geq 0)$؛ $F_X = 1 - e^{-\lambda x}$. ■

- **النتيجة:** أسّية تنازليّة.
- **الربط بالذكاء الاصطناعي:** «زمن الانتظار/الفشل» = أسّي — يظهر في SDE (ch12.7).

مثال (12-4.13).

- **المعطيات:** توزيع مختلط (كتلة عند 0 + سلس).
- **المطلوب:** صفّ CDF.
- **الحل:**

١. قفزة عند 0 بارتفاع p ثمّ جزء سلس صاعد. ■

- **النتيجة:** قفزة + انحناء.
- **الربط بالذكاء الاصطناعي:** «بيانات بقيم مفقودة/صفر» = توزيع مختلط — شائع فعلياً.

مثال (13-4.13).

- **المعطيات:** CDF التجريبي F_n.
- **المطلوب:** اربط بـ (8-7.10).
- **الحل:**

١. $F_n(x) = \frac{1}{n}\sum \mathbf{1}_{\{X_i \leq x\}}$ = CDF للتوزيع التجريبي. ■

- **النتيجة:** متوسّط عيّنات.
- **الربط بالذكاء الاصطناعي:** «CDF التجريبي» = جسر train→توزيع (أساس تقييم/GLIVE).

مثال (14-4.13).

- **المعطيات:** متغيّران X, Y، CDF مشترك $F_{X,Y}$.

- **المطلوب:** العلاقة بالهامشي.
- **الحل:**
١. $F_X(x) = F_{X,Y}(x, \infty)$. ■
- **النتيجة:** هامش = تقييد مشترك.
- **الربط بالذكاء الاصطناعي:** «توزيع هامشي = تهميش مشترك» — أساس بايز/الاستدلال.

مثال (4.13-15).

- **المعطيات:** توزيعان بـ CDF متطابقة.
- **المطلوب:** هل هما نفس التوزيع؟
- **الحل:**
١. نعم — F تحدّد $\mathbb{P}_X$ uniquely. ■
- **النتيجة:** تكافؤ التوزيعات = تطابق CDF.
- **الربط بالذكاء الاصطناعي:** «مقارنة نموذجين = مقارنة «CDF/KDE — تقييم التوليد.

التعريف

dir="ltr"> <div

Definition 1.5.13 (Conditional & independence). For $\mathbb{P}(B) > 0$:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Events A, B are **independent** iff $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$. theorem: Bayes'.

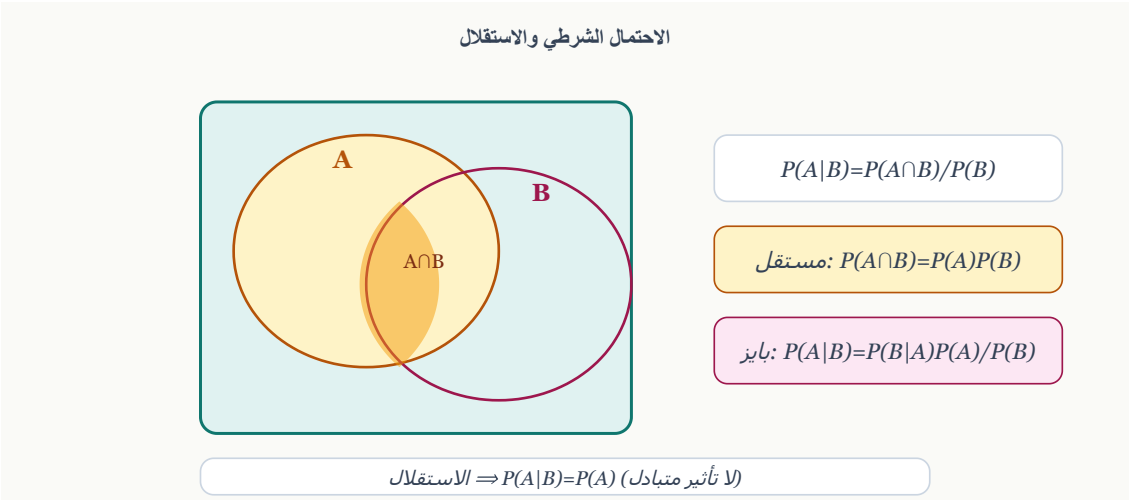
$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(B \mid A)\mathbb{P}(A)}{\mathbb{P}(B)}.$$

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}; \qquad \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B) \ \text{(indep.)}. \tag{4.13}$$

النظرية 1.5.13 (الاستقلال التامّ): المتغيّرات X, Y مستقلّتان iff $\mathbb{P}_{X,Y} = \mathbb{P}_X \otimes \mathbb{P}_Y$ (منتج قياسات، من 11-2.10).

جدول الرموز

الرمز	الاسم	المعنى
$\mathbb{P}(A \mid B)$	احتمال شرطي	احتمال A بشرط B
$\perp$	استقلال	لا تأثير متبادل
Bayes	مبرهنة بايز	عكس الشرطيّة



شكل ٤٠١٣: *
الاحتمال الشرطي والاستقلال

رسم توضيحي

<figure> الشكل<figcaption> Venn :4.13 يُظهر $A \cap B$ (المظلّلة). الاحتمال الشرطي يعيد تطبيع المساحة إلى B؛ الاستقلال يجعل $P(A \mid B) = P(A)$.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
نسيان شرط $\mathbb{P}(B) > 0$	القسمة على صفر	تحقّق قبل التعريف
خلط الاستقلال بعدم التقاطع	مستقلّان قد يتقاطعان	$P(A \cap B) = P(A)P(B)$
اعتبار $P(A \mid B) = P(B \mid A)$	غير متماثل	بايز يقلب بـ $P(A)/P(B)$
تجاهل أنّ الاستقلال ليس توارثياً	قد يفشل لثلاثة	افحص الاستقلال التامّ

أمثلة محلولة على الاحتمال الشرطي والاستقلال (15 مثالاً)

مثال (13.5-1).

- **المعطيات:** نرد، A «زوجي»، B «>3».
- **المطلوب:** $\mathbb{P}(A \mid B)$.
- **الحل:**

١. $B = \{4,5,6\}$، $A \cap B = \{4,6\} \Rightarrow 2/3$. ■

- **النتيجة:** $2/3$.
- **الربط بالذكاء الاصطناعي:** «تصفية شرطية» = تقييم مخرجات ضمن فئة.

مثال (13.5-2).

- **المعطيات:** $\mathbb{P}(A \cap B) = 0.1, \mathbb{P}(B) = 0.4$.
- **المطلوب:** $\mathbb{P}(A \mid B)$.
- **الحل:**

١. $0.1/0.4 = 0.25$. ■

- **النتيجة:** 0.25.
- **الربط بالذكاء الاصطناعي:** «دقّة مشروطة» = $\mathrm{P}(\text{صحيح} \mid \text{فئة})$ — مقياس تصنيف.

مثال (13.5-3).

- **المعطيات:** قاعدة الضرب.
- **المطلوب:** اشتقق $\mathbb{P}(A \cap B)$.
- **الحل:**

١. $\mathbb{P}(A \cap B) = \mathbb{P}(A \mid B)\mathbb{P}(B)$. ■

- **النتيجة:** ضرب شرطي.
- **الربط بالذكاء الاصطناعي:** «احتمال تسلسل» = ضرب مشروط — نماذج السلاسل (HMM).

مثال (13.5-4).

- **المعطيات:** سلسلة شرط $\mathbb{P}(x_1, \dots, x_n)$.
- **المطلوب:** قاعدة السلسلة.
- **الحل:**

١. $\mathbb{P}(x_1, \dots, x_n) = \mathbb{P}(x_1) \prod_{i=2}^{n} \mathbb{P}(x_i \mid x_{<i})$. ■

- **النتيجة:** تحليل مشروط.
- **الربط بالذكاء الاصطناعي:** «نموذج لغوي = سلسلة شرطية» — LLM. autoregressive

مثال (13.5-5).

- **المعطيات:** مبرهنة بايز.
- **المطلوب:** اشتقاقها.
- **الحل:**

١. $\mathbb{P}(A \mid B)\mathbb{P}(B) = \mathbb{P}(A \cap B) = \mathbb{P}(B \mid A)\mathbb{P}(A) \implies$ الباقي. ■

- **النتيجة:** بايز.
- **الربط بالذكاء الاصطناعي:** «عكس السبب↔الملاحظة» = أساس الاستدلال البايزي.

مثال (13.5-6).

- **المعطيات:** اختبار مرض: حساسية 99%، نوعية 99%، انتشار 1%.
- **المطلوب:** $\mathbb{P}(\text{مرض} \mid +)$.
- **الحل:**

١. بايز: $(0.99 \cdot 0.01)/(0.99 \cdot 0.01 + 0.01 \cdot 0.99) = 0.5$. ■

- **النتيجة:** 50% فقط!
- **الربط بالذكاء الاصطناعي:** «نفخّ القاعدة الشاذة» — يفسّر لماذا نحتاج بايز لا دقّة خام.

مثال (13.5-7).

- **المعطيات:** A, B مستقلّان، $\mathbb{P}(A) = 0.4, \mathbb{P}(B) = 0.5$.
- **المطلوب:** $\mathbb{P}(A \cap B)$.
- **الحل:**

١. $0.4 \cdot 0.5 = 0.2$. ■

- **النتيجة:** 0.2.
- **الربط بالذكاء الاصطناعي:** «ميزات مستقلة» = ضرب احتمالات (Naive Bayes).

مثال (13.5-8).

- **المعطيات:** A, B منفصلان (متنافيان).
- **المطلوب:** هل مستقلّان؟
- **الحل:**

١. لا (إلا إن كان أحدهما باحتمال 0)؛ $P(A \cap B) = 0 \neq P(A)P(B)$. ■

- **النتيجة:** منفصل $\neq$ مستقلّ.
- **الربط بالذكاء الاصطناعي:** «فئتان متنافيتان غير مستقلّتين» — خطأ شائع في التصنيف.

مثال (13.5-9).

- **المعطيات:** استقلال زوجي مقابل تامّ.

- **المطلوب:** الفرق.
- **الحل:**

١. الزوجي: كلّ زوج؛ التامّ: كلّ تقاطع = جداء كلّ الهوامش (أقوى). ■

- **النتيجة:** التامّ أقوى.
- **الربط بالذكاء الاصطناعي:** «استقلال متبادل للميزات» = افتراض Bayes Naive المبسّط.

مثال (10-5.13).

- **المعطيات:** X, Y متغيّران عشوائيان.
- **المطلوب:** تعريف الاستقلال.
- **الحل:**

١. $\mathbb{P}_{X,Y} = \mathbb{P}_X \otimes \mathbb{P}_Y$ (منتج قياسات). ■

- **النتيجة:** منتج توزيعات.
- **الربط بالذكاء الاصطناعي:** «مكوّنات مستقلة» = ضرب كثافات — Factorized models.

مثال (11-5.13).

- **المعطيات:** استقلال مشروط $X \perp Y \mid Z$.
- **المطلوب:** المعنى.
- **الحل:**

١. $\mathbb{P}(X, Y \mid Z) = \mathbb{P}(X \mid Z)\mathbb{P}(Y \mid Z)$. ■

- **النتيجة:** استقلال بعد تثبيت Z.
- **الربط بالذكاء الاصطناعي:** «الرسوم البيانية الاحتمالية» (PGM) تُبنى على الاستقلال المشروط.

مثال (12-5.13).

- **المعطيات:** قانون الاحتمال الكلّي.
- **المطلوب:** الصيغة.
- **الحل:**

١. إن B_i حصرية شاملة: $\mathbb{P}(A) = \sum \mathbb{P}(A \mid B_i)\mathbb{P}(B_i)$. ■

- **النتيجة:** تجميع شرطي.
- **الربط بالذكاء الاصطناعي:** «المزيج الغاوسي» = مجموع مشروط بالمكوّن — GMM.

مثال (13-5.13).

- **المعطيات:** مسألة مونتي هول.
- **المطلوب:** هل تبديل الباب يضاعف الفوز؟
- **الحل:**

١. بايز: $\mathbb{P}(\text{سيّارة} \mid \text{تبديل}) = 2/3 > 1/3$. ■

- **النتيجة:** نعم، يضاعف.
- **الربط بالذكاء الاصطناعي:** «تحديث الاحتمال بالملاحظة» = جوهر التعلّم المتسلسل.

مثال (14-5.13).

- **المعطيات:** الاستدلال البايزي في ML.
- **المطلوب:** الصيغة.
- **الحل:**

١. $\mathbb{P}(\theta \mid D) \propto \mathbb{P}(D \mid \theta)\mathbb{P}(\theta)$ (ما بعد $\propto$ قبل × مُلاحِظ). ■

- **النتيجة:** ما بعد = قبل × مُلاحِظ / دليل.
- **الربط بالذكاء الاصطناعي:** «التعلّم = تحديث الاعتقاد» — deep Bayesian learning.

مثال (15-5.13).

- **المعطيات:** افتراض Naive Bayes.
- **المطلوب:** الصيغة المبسّطة.
- **الحل:**

١. $\mathbb{P}(y \mid x_1, \dots, x_d) \propto \mathbb{P}(y) \prod_i \mathbb{P}(x_i \mid y)$. ■

- **النتيجة:** جداء مشروط.
- **الربط بالذكاء الاصطناعي:** «تسريع التصنيف» = استقلال ميزات مُفترض — نموذج خطّي قويّ.

التعريف

dir="ltr"> <div
integral Lebesgue–Stieltjes the is X of expectation The **(Expectation). 1.6.13 Definition**
distribution: its of

$$\mathbb{E}[X] = \int_{\Omega} X \, d\mathbb{P} = \int_{\mathbb{R}} x \, dF_X(x).$$

.$\mathbb{E}[X] = \int x \, f_X(x) \, dx$ continuous: for ;$\mathbb{E}[X] = \sum_x x \, \mathbb{P}(X = x)$ discrete: For

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \, dF_X(x). \tag{5.13}$$

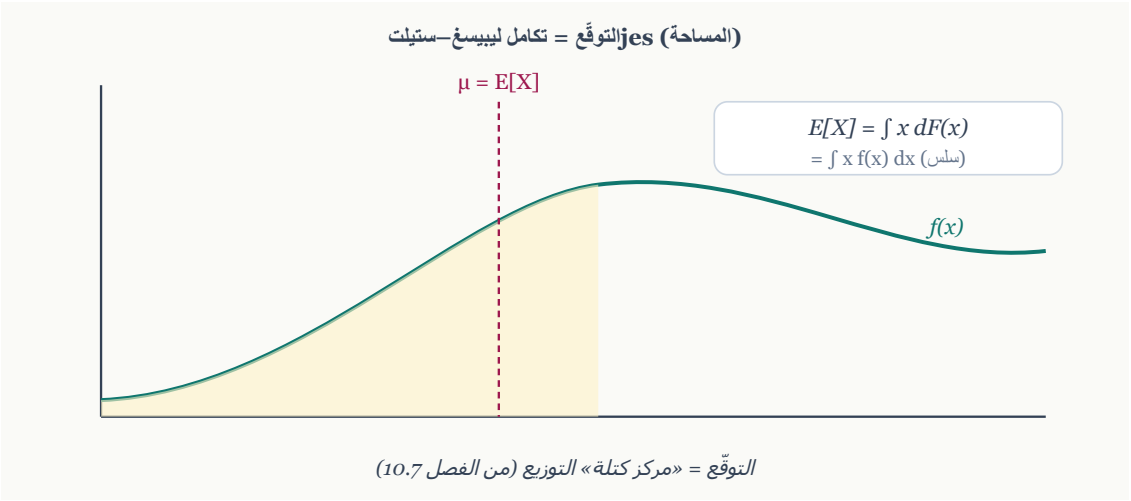
النظرية 1.6.13 (الخطيّة والتحويل): $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$؛ وإن g قياسية فـ $\mathbb{E}[g(X)] = \int g(x) \, dF_X(x)$.

جدول الرموز

الرمز	الاسم	المعنى
$\mathbb{E}[X]$	التوقّع	«مركز كتلة» التوزيع
$\int x \, dF$	تكامل Stieltjes	من الفصل 7.10
$\mathbb{E}[g(X)]$	توقّع دالة	تكامل g بـ $\mathbb{P}_X$

رسم توضيحي

<figure> الشكل<figcaption> 5.13: $\mathbb{E}[X]$ هو «مركز كتلة» الكثافة — مساحة التكامل $\int x f(x) dx$ (المظلّل)،



شكل ٥.١٣: *
التوقّع كمساحة تحت الكثافة

وتقابل تكامل ليبيسغ–ستيلتjes $\int x \, dF$ من الفصل 7.10. الخط المتقطّع هو المتوسّط μ</figcaption>. </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط $\mathbb{E}[X]$ مع «القيمة الشائعة»	هو متوسّط مرجّح	وزنه الاحتمال
نسيان أنّ $\mathbb{E}[X]$ قد يكون ∞	توزيعات ذيل ثقيل	افحص التقارب
اعتبار $\mathbb{E}[g(X)] = g(\mathbb{E}[X])$	خطأ عامّ	صحيح فقط خطّي/محدّب خاصّ
استخدام PDF للمنفصل	بلا كثافة	استخدم الجمع

أمثلة محلولة على التوقّع (15 مثالاً)

مثال (13.6-1).

- **المعطيات:** عرّف $\mathbb{E}[X] = \int X \, d\mathbb{P}$.
- **الحل:**

١. هو تكامل ليبيسغ لـ X بقياس $\mathbb{P}$ (من 10.5). ■

- **النتيجة:** توقّع = تكامل.
- **الربط بالذكاء الاصطناعي:** «المخاطرة المتوقّعة» = $\mathbb{E}[L]$ — هدف التدريب.

مثال (13.6-2).

- **المعطيات:** $\mathbb{E}[X] = \int x \, dF_X(x)$.
- **المطلوب:** اربط بـ (10.7.1).
- **الحل:**

١. F_X تولّد $\mathbb{P}_X = \mu_F$؛ فالتكامل هو Stieltjes من الفصل 10.7. ■

- **النتيجة:** تطابق تامّ.
- **الربط بالذكاء الاصطناعي:** «كل توقّع = Stieltjes» — يوحّد الإحصاء بالقياس.

مثال (13.6-3).

- **المعطيات:** X منفصلة.
- **المطلوب:** $\mathbb{E}[X]$.
- **الحل:**

١. $\sum_x x \, \mathbb{P}(X = x)$. ■

- **النتيجة:** مجموع مرجّح.
- **الربط بالذكاء الاصطناعي:** «متوسّط فئوي» = $\sum$ احتمال×قيمة — خرج softmax×logits.

مثال (4-6.13).

- **المعطيات:** X سلس.
- **المطلوب:** $\mathbb{E}[X]$.
- **الحل:**
١. $\int x\, f_X(x) dx$. ■
- **النتيجة:** تكامل كثافة.
- **الربط بالذكاء الاصطناعي:** «متوسّط مستمرّ» = تكامل كثافة — تقييم التوزيعات.

مثال (5-6.13).

- **المعطيات:** أثبت الخطيّة.
- **الحل:**
١. $\mathbb{E}[aX+b] = \int (ax+b) d\mathbb{P} = a\mathbb{E}[X] + b$ (خطيّة التكامل 4.5.10). ■
- **النتيجة:** خطّي.
- **الربط بالذكاء الاصطناعي:** «متوسّط الخسارة = خسارة المتوسّط» — يبرّر جمع الخسائر.

مثال (6-6.13).

- **المعطيات:** A حدث.
- **المطلوب:** $\mathbb{E}[\mathbf{1}_A]$.
- **الحل:**
١. $= 1 \cdot \mathbb{P}(A) + 0 \cdot \mathbb{P}(A^c) = \mathbb{P}(A)$. ■
- **النتيجة:** توقّع المؤشّر = احتمال.
- **الربط بالذكاء الاصطناعي:** «دقّة = مؤشّر[E صحيح]» — يربط الدقّة بالتوقّع.

مثال (7-6.13).

- **المعطيات:** $\mathbb{E}[g(X)]$.
- **الحل:**
١. $= \int g(x)\, dF_X(x)$ (تكامل بالقياس المدفوع). ■
- **النتيجة:** توقّع دالة.
- **الربط بالذكاء الاصطناعي:** «خسارة على العيّنات = «E[g(X)] — أساس كلّ objective.

مثال (13.6-8).

- **المعطيات:** $X \sim \text{Bernoulli}(p)$.
- **المطلوب:** $\mathbb{E}[X]$.
- **الحل:**
١. $1 \cdot p + 0 \cdot (1-p) = p$. ■
- **النتيجة:** p.
- **الربط بالذكاء الاصطناعي:** «احتمال الفئة الموجبة = توقّعها» — خرج sigmoid.

مثال (13.6-9).

- **المعطيات:** $X \sim \text{Unfiorm}[a,b]$.
- **المطلوب:** $\mathbb{E}[X]$.
- **الحل:**
١. $\int_a^b x/(b-a)\,dx = (a+b)/2$. ■
- **النتيجة:** المنتصف.
- **الربط بالذكاء الاصطناعي:** «المتوسّط الموحّد = منتصف النطاق» — تهيئة الموحّد.

مثال (13.6-10).

- **المعطيات:** $X \sim \text{Exp}(\lambda)$.
- **المطلوب:** $\mathbb{E}[X]$.
- **الحل:**
١. $\int_0^\infty x\lambda e^{-\lambda x}dx = 1/\lambda$. ■
- **النتيجة:** $1/\lambda$.
- **الربط بالذكاء الاصطناعي:** «متوسّط الزمن» = $1/\lambda$ — يظهر في SDE (ch12.7).

مثال (13.6-11).

- **المعطيات:** مجموع مؤشّرات $S = \sum \mathbf{1}_{A_i}$.
- **المطلوب:** $\mathbb{E}[S]$.
- **الحل:**
١. بخطيّة: $\sum \mathbb{P}(A_i)$. ■
- **النتيجة:** مجموع الاحتمالات.
- **الربط بالذكاء الاصطناعي:** «عدّ الأحداث المتوقّع» = مجموع احتمالاتها — تقدير العدّ.

مثال (13-6.12).

- **المعطيات:** $Y = g(X)$ بتوزيع $\mathbb{P}_Y$.
- **المطلوب:** $\mathbb{E}[Y] = \mathbb{E}[g(X)]$.
- **الحل:**

١. $\int y \, d\mathbb{P}_Y(y) = \int g(x) \, d\mathbb{P}_X(x)$ (تغيير متغيّر/قياس مدفوع). ■

- **النتيجة:** تكافؤ.
- **الربط بالذكاء الاصطناعي:** «توقّع تحويل = تكامل بالتوزيع الجديد» — reparameterization.

مثال (13-6.13).

- **المعطيات:** X, Y مستقلّان.
- **المطلوب:** $\mathbb{E}[XY]$.
- **الحل:**

١. $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ (منتج قياسات). ■

- **النتيجة:** تفكّك تامّ.
- **الربط بالذكاء الاصطناعي:** «توقّع جداء مستقلّ = جداء التوقّعات» — تبسيط التباين/الترابط.

مثال (14-6.13).

- **المعطيات:** $\mathbb{E}[X] = \lim \mathbb{E}[X_n]$ متى؟
- **المطلوب:** اربط بـ DCT (3.6.10).
- **الحل:**

١. إن $X_n \to X$ و $|X_n| \le Y$ بـ $\mathbb{E}[Y] < \infty \implies$ التبادل مضمون. ■

- **النتيجة:** DCT للتوقّعات.
- **الربط بالذكاء الاصطناعي:** «تبادل حدّ/توقّع» يبرّر تحويل مجموع خسائر إلى E[L].

مثال (15-6.13).

- **المعطيات:** متوسّط عيّنات $\bar{X}_n \to \mathbb{E}[X]$؟

- **المطلوب:** اربط بـ SGD/stochastic (4.6.12).
- **الحل:**

١. $\bar{X}_n = \frac{1}{n}\sum X_i$ يتقارب لتوقّع (قانون الأعداد الكبيرة) — نواة تحويل train→expected. risk ■

- **النتيجة:** جسر العيّنات والتوزيع.
- **الربط بالذكاء الاصطناعي:** «متوسّط الدُفعة ≈ توقّع» = أساس تقدير المخاطرة (ch30).

النظريات والصيغ

dir="ltr"> <div

Definition 1.7.13 (Modes of convergence). Let X_n, X be random variables.

- **Almost sure (a.s.):** $\mathbb{P}(\lim X_n = X) = 1$.
- **In probability:** $\forall \varepsilon > 0,\ \mathbb{P}(|X_n - X| > \varepsilon) \to 0$.
- **In L^p:** $\mathbb{E}[|X_n - X|^p] \to 0$.
- **In distribution:** $F_{X_n}(x) \to F_X(x)$ at points of continuity.

Lemma 1.7.1 Borel–Cantelli. If $\sum \mathbb{P}(A_n) < \infty$ then $\mathbb{P}(A_n \text{ i.o.}) = 0$.

$$\text{a.s.} \ \Rightarrow\ \text{probability in} \ \Rightarrow\ \text{distribution in}; \qquad L^p \Rightarrow \text{prob} \ (p \geq 1). \tag{6.13}$$

النظرية 1.7.13 (التضمينات): التقارب اليقينيّ أقوى من الاحتماليّ، والاحتماليّ أقوى من بالتوزيع؛ و L^p يستلزم الاحتماليّ.

جدول الرموز

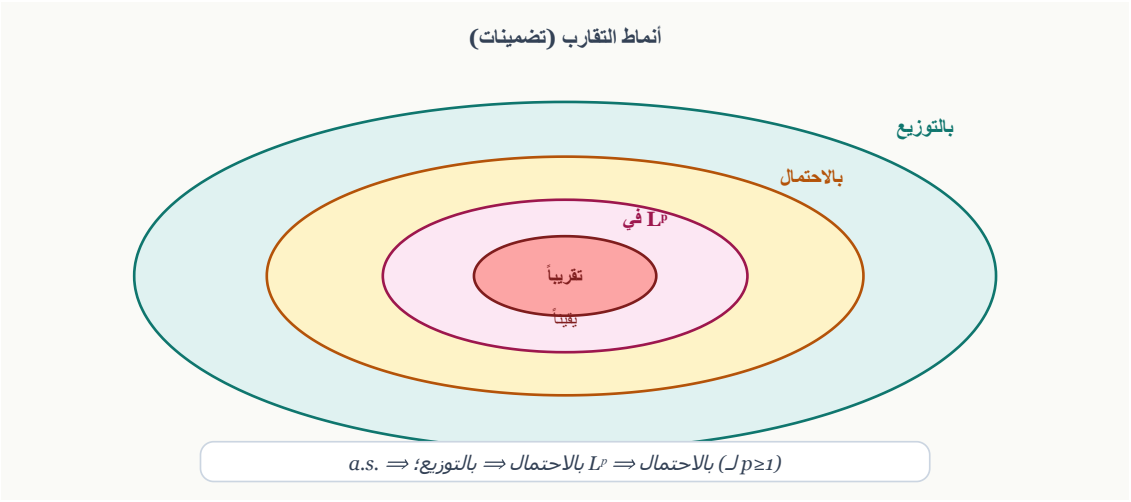
الرمز	الاسم	المعنى
a.s.	تقريباً يقيناً	عدا مجموعة احتمالها 0
i.p.	بالاحتمال	الخطأ يتلاشى احتمالياً
i.d.	بالتوزيع	CDF تتقارب

رسم توضيحي

<figure> الشكل 6.13: هرم التضمين: a.s. (الداخل) ⟹ بالاحتمال ⟹ بالتوزيع (الخارج)؛ و L^p يستلزم بالاحتمال. كلّ نمط أضعف كلّما اتسعت الدائرة.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«بالتوزيع ⟹ بالاحتمال»	العكس صحيح	التوزيع أضعف
نسيان Borel-Cantelli يحتاج جمعاً منتهياً	∞ لا يكفي	انتبه للفرض
خلط تقارب العيّنات بالتوزيع	مفهومان مختلفان	a.s. أقوى
اعتبار L^1 يستلزم a.s.	لا يستلزم	يستلزم الاحتمال فقط



شكل ٦.١٣: *
تضمينات أنماط التقارب

أمثلة محلولة على أنماط التقارب (15 مثالاً)

مثال (13.7-1).

- **المعطيات:** $X_n \to X$ a.s.
- **المطلوب:** عرّف.
- **الحل:**

١. $\mathbb{P}(\{\omega : \lim X_n(\omega) = X(\omega)\}) = 1$. ■

- **النتيجة:** تقارب يقينيّ تقريباً.
- **الربط بالذكاء الاصطناعي:** «تقارب التدريب على كلّ عيّنة» = قوة قانون الأعداد الكبيرة القويّ.

مثال (13.7-2).

- **المعطيات:** $X_n \to X$ بالاحتمال.
- **المطلوب:** عرّف.
- **الحل:**

١. $\forall \varepsilon > 0 : \mathbb{P}(|X_n - X| > \varepsilon) \to 0$. ■

- **النتيجة:** الخطأ يتلاشى احتمالياً.
- **الربط بالذكاء الاصطناعي:** SGD» يتقارب بالاحتمال» — وصف نموذجي لتقارب المحسّنات.

مثال (13.7-3).

- **المعطيات:** $X_n \to X$ في L^p.
- **المطلوب:** عرّف.
- **الحل:**

١. $\mathbb{E}[|X_n - X|^p] \to 0$. ■

- **النتيجة:** تقارب بالتوقّع.
- **الربط بالذكاء الاصطناعي:** «تقارب MSE/L1» = تقارب L^2/L^1 للخسارة.

مثال (13.7-4).

- **المعطيات:** $X_n \to X$ بالتوزيع.
- **المطلوب:** عرّف.
- **الحل:**

١. $F_{X_n}(x) \to F_X(x)$ عند نقاط استمرار F_X. ■

- **النتيجة:** تقارب CDF.
- **الربط بالذكاء الاصطناعي:** «توزيع المخرجات يتقارب» = تقييم نموذج توليدي (FID يستخدمه).

مثال (13.7-5).

- **المعطيات:** رتّب الأنماط بالقوة.
- **المطلوب:** التضمينات.
- **الحل:**

١. a.s. $\Rightarrow$ احتمال $\Rightarrow$ توزيع؛ و $L^p \Rightarrow$ احتمال $(p \geq 1)$. ■

- **النتيجة:** هرم.
- **الربط بالذكاء الاصطناعي:** «أقوى تقارب = ضمان تعميم أقوى» — يسبق نظريات PAC (ch31).

مثال (13.7-6).

- **المعطيات:** متوسّط قِمار $\bar{X}_n \to \mu$ a.s.

- **المطلوب:** ما النمط؟
- **الحل:**

١. قانون الأعداد الكبيرة القويّ $\Longrightarrow$ a.s. ■

- **النتيجة:** a.s.
- **الربط بالذكاء الاصطناعي:** «متوسّط الدُفعة يقترب من المتوسّط الحقيقي» — حجر الزاوية.

مثال (13.7-7).

- **المعطيات:** $X_n = 1/n$ (حتمي).
- **المطلوب:** أيّ أنماط؟
- **الحل:**

١. يتقارب حتمياً $\Longrightarrow$ كلّ الأنماط. ■

- **النتيجة:** جميعها.
- **الربط بالذكاء الاصطناعي:** «معدّل تعلّم يتلاشى حتمياً» = تقارب معدّل التعلّم (LR decay).

مثال (13.7-8).

- **المعطيات:** X_n بـ $\mathbb{P}(X_n = 1) = 1/n$، وإلا 0.
- **المطلوب:** أيّ تقارب؟
- **الحل:**

١. $0 \to$ بالاحتمال (ليس a.s. إن $\sum 1/n = \infty$). ■

- **نتيجة:** احتمال لا a.s.
- **الربط بالذكاء الاصطناعي:** «ضجيج يتلاشى احتمالياً لا يقينياً» — يميّز SGD عن GD.

مثال (13.7-9).

- **المعطيات:** Borel-Cantelli 1: $\sum \mathbb{P}(A_n) < \infty$.
- **المطلوب:** استنتج.
- **الحل:**

١. $\mathbb{P}(A_n \text{ i.o.}) = 0$ $\Longrightarrow$ الأحداث تتوقّف أخيراً باحتمال 1. ■

- **نتيجة:** توقّف شبه-يقيني.
- **الربط بالذكاء الاصطناعي:** «احتمال خطأ متكرر مجموعه منتهٍ $\Longrightarrow$ يتلاشى» — أساس حدود التعميم.

مثال (13.7-10).

- **المعطيات:** Borel-Cantelli 2 (مستقلّة) + $\sum \mathbb{P}(A_n) = \infty$.
- **المطلوب:** الاستنتاج.
- **الحل:**

١. $\mathbb{P}(A_n \text{ i.o.}) = 1$. ■

- **نتيجة:** تكرار لا ينتهي.
- **الربط بالذكاء الاصطناعي:** «إن كثر الخطأ المستقلّ بلا حدّ $\Longrightarrow$ يحدث دائماً» — تحذير في التعلّم المستمرّ.

مثال (13.7-11).

- **المعطيات:** $X_n \to X$ في L^1 و g مستمرّة.
- **المطلوب:** ماذا عن $g(X_n)$؟
- **الحل:**

١. رسمياً نحتاج شروطاً، لكنّه يوحّد مع تقارب التوزيع (continuous mapping). ■

- **نتيجة:** استقرار التحويل.
- **الربط بالذكاء الاصطناعي:** «تحويل المخرجات يحفظ التقارب» — مفيد في التقييم.

مثال (13.7-12).

- **المعطيات:** بالتوزيع أضعف من الباقي.
- **المطلوب:** لماذا؟
- **الحل:**

١. CDF تتقارب لكنّ القيم الفردية قد لا (مثل $X_n = -X$ نفس التوزيع). ■

- **نتيجة:** أضعف نمط.
- **الربط بالذكاء الاصطناعي:** «مطابقة التوزيع لا تعني مطابقة العيّنات» — يفرّق KL عن المسافة.

مثال (13.7-13).

- **المعطيات:** CLT: $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$.
- **المطلوب:** ما نمط التقارب؟
- **الحل:**

١. بالتوزيع (يقيناً لا احتمال). ■

- **نتيجة:** i.d.
- **الربط بالذكاء الاصطناعي:** «تقارب التوزيع الطبيعي» = أساس فواصل الثقة وتقدير التباين.

مثال (13.7-14).

- **المعطيات:** لماذا تهمّ الأنماط في ML؟
- **المطلوب:** اربط بالتعميم.
- **الحل:**

١. تقارب test→train «بالتوزيع/الاحتمال» هو ما تضمنه نظريات PAC/Rademacher (ch31). ■

- **نتيجة:** أساس نظرية التعلّم.
- **الربط بالذكاء الاصطناعي:** «فهم أنماط التقارب = فهم متى يتعلّم النموذج فعلاً».

مثال (13.7-15).

- **المعطيات:** علاقة بالفصل 17 (تركيز) و18 (استدلال).
- **المطلوب:** استشر.
- **الحل:**

١. متراجحات التركيز (Markov/Chebyshev/Hoeffding) تربط L^1 واحتمال الانحراف — فصول لاحقة. ■

- **نتيجة:** جسر للمستقبل.
- **الربط بالذكاء الاصطناعي:** «هذا الفصل أسّس القياس؛ التالي يبني الاحتمالات والتقدير عليه» — انتقال للجزء الثالث.

خيط الفصل

١. **فضاء كولموغروف (2.13):** $(\Omega, \mathcal{F}, \mathbb{P})$ = قياس بـ $\mathbb{P}(\Omega) = 1$ (من الفصل 10).

٢. **المتغيّر العشوائي (3.13):** X دالة قياسية؛ توزيعها قياس مدفوع $\mathbb{P}_X$.

٣. **التوزيعات (4.13):** CDF/PMF/PDF تحدّد التوزيع uniquely، وCDF = measure Stieltjes (7.10).

٤. **الشرطي والاستقلال (5.13):** بايز والمنتج — أساس الاستدلال والرسوم البيانية.

٥. **التوقّع (6.13):** $\mathbb{E}[X] = \int x\, dF_X(x)$ = تكامل ليبيسغ–ستيلتjes (7.10).

٦. **التقارب (7.13):** a.s. $\Rightarrow$ احتمال $\Rightarrow$ توزيع؛ وبوريل-كانتيللي — أساس التعميم (الجزء السادس).

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
$(\Omega, \mathcal{F}, \mathbb{P})$	كل إحصاء في الفصول 14–19
X قياسية / $\mathbb{P}_X$	توزيعات، بايز
$\mathbb{E}[X] = \int x\, dF$	مخاطرة متوقّعة، KL (26)
Stieltjes = CDF	ربط بـ ch10.7
أنماط التقارب	(31) Rademacher / PAC، (6.12) SGD
بايز / الاستقلال	الشبكات البايزية، Bayes Naive

١. عرّف فضاء احتمال وأثبت $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ من المحاور.

٢. أثبت قاعدة الشمول والاستبعاد لـ $\mathbb{P}(A \cup B \cup C)$.

٣. لـ $X : \Omega \to \mathbb{R}$، أثبت أنّ $\{X \le x\} \in \mathcal{F}$ لكل x يكفي لقياسيّتها.

٤. لـ X منفصلة بقيم $\{1, 2, 3\}$ واحتمالات $0.2, 0.3, 0.5$، اكتب $\mathbb{P}_X$ كمجموع دلتات.

٥. أثبت أنّ $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$ من خطيّة التكامل.

٦. لـ Unfiorm$[a, b]$، اشتقّ F_X والكثافة و $\mathbb{E}[X]$.

٧. عرّف CDF واذكر خصائصها الأربع.

٨. لـ $X \sim \text{Exp}(\lambda)$، احسب $\mathbb{E}[X]$ و $\mathbb{P}(X > t)$.

٩. اشتقّ مبرهنة بايز من تعريف الاحتمال الشرطي.

١٠. في مثال الاختبار الطبّي، عمّم لانتشار r واحسب $\mathbb{P}(+ \mid \text{مرض})$.

١١. أثبت أنّ الاستقلال لا يستلزم عدم التقاطع (مثال منفصلان باحتمال 0).

١٢. لـ X, Y مستقلّان، أثبت $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.

١٣. اربط CDF بـ قياس ليبيسغ–ستيلتjes (7.10) رسمياً.

١٤. عرّف التقارب بالاحتمال وبالتوزيع واذكر أيّهما أضعف.

١٥. طبّق Borel-Cantelli 1 على A_n بـ $\mathbb{P}(A_n) = 1/n^2$.

١٦. لـ $X_n = 1/n$ حتميّاً، حدّد كلّ أنماط التقارب.

١٧. X_n بـ $\mathbb{P}(X_n = 1) = 1/n$ — هل تتقارب a.s.؟ (استخدم Borel-Cantelli).

١٨. أثبت أنّ تقارب L^p يستلزم بالاحتمال لـ $p \geq 1$ (عبر متراجحة ماركوف).

١٩. عبّر $\mathbb{E}[g(X)]$ كتكامل Stieltjes واربطه بـ (6-7.10).

٢٠. تحدٍّ تركيبي: «لماذا متوسّط الدُفعة يقارب المخاطرة المتوقّعة؟» — اجمع: $\bar{X}_n = \frac{1}{n}\sum X_i$ (6.13)، التوزيع التجريبي (13-4.13)، والتقارب a.s. (7.13) كأساس لـ risk expected في الجزء السادس.

- **فضاء كولموغروف (1.13):** $(\Omega, \mathcal{F}, \mathbb{P})$ قياس بـ $\mathbb{P}(\Omega) = 1$ وجمع عدّي — حالة خاصّة من الفصل 10.
- **متغيّر عشوائي (2.13):** دالة قياسية؛ $\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B))$ قياس مدفوع.
- **توزيع (3.13):** $F_X(x) = \mathbb{P}(X \leq x)$ تحدّد التوزيع؛ PDF = مشتقّتها لـ السلس.
- **شرطي/استقلال (4.13):** $\mathbb{P}(A \mid B) = \mathbb{P}(A \cap B)/\mathbb{P}(B)$؛ بايز والمنتج.
- **توقّع (5.13):** $\mathbb{E}[X] = \int x\, dF_X(x)$ = ليبيسغ–ستيلتjes (7.10).
- **التقارب (6.13):** a.s. $\Longrightarrow$ احتمال $\Longrightarrow$ توزيع؛ $L^p \Longrightarrow$ احتمال؛ Borel-Cantelli.

الرمز	المعنى	أين عُرّف
$(\Omega, \mathcal{F}, \mathbb{P})$	فضاء الاحتمال	(1.13)
$\mathbb{P}_X$	توزيع X مدفوع	(2.13)
F_X	CDF	(3.13)
$\mathbb{P}(A \mid B)$	احتمال شرطي	(4.13)
$\mathbb{E}[X]$	التوقّع	(5.13)
i.d. / i.p. / a.s.	أنماط تقارب	(6.13)

١. A. Kolmogorov, (1933/1950). *Probability of Theory the of Foundations* — المحاور الكولموغروفية الأصلية.

٢. P. Billingsley, (1995). *Measure and Probability*, 3rd ed., Wiley — الربط المنهجي بين القياس والاحتمال (الفصل 10 هنا).

٣. D. Williams, (1991). *Martingales with Probability*, CUP — فضاءات الاحتمال والتقارب بأسلوب قياسي.

٤. P. Protter, & J. Jacod, (2004). *Essentials Probability*, Springer — مقدمة مكثّفة ببنية قياسية.

٥. D. Stirzaker, & G. Grimmett, (2001). *Processes Random and Probability*, 3rd ed., OUP — أمثلة شرطيّة واستقلال.

٦. K. Murphy, (2022). *Probabilistic Machine Learning*, MIT Press — الاستدلال البايزي والتوزيعات في ML.

٧. C. Bishop, (2006). *Pattern Recognition and Machine Learning*, Springer — التوزيعات والتوقّع والتقارب في السياق التطبيقي.

٨. S., Boucheron, G. Lugosi, & P. Massart (2013). *Concentration Inequalities*, OUP — يبني على أنماط التقارب نحو التعميم (الفصول 17، 31 لاحقاً).

المتغيرات العشوائية والتوزيعات القياسية

في الفصل 13 بنينا «فضاء الاحتمال» $(\Omega, \mathcal{F}, \mathbb{P})$ كحالة خاصة من نظرية القياس. لكن التعلم الآلي لا يتعامل مباشرةً مع النواتج $\omega \in \Omega$؛ إنه يتعامل مع **أعداد**: درجة احتمال، خطأ، زمن استجابة، متجهة ميزات. لذلك نُمرِّر ω عبر **متغيّر عشوائي** $X : \Omega \to \mathbb{R}^d$ لنحصل على كمّيّات قابلة للحساب.

هذا الفصل هو «قاموس» توزيعات الاحتمال: المجموعة القياسية من الأشكال التي تظهر في كل خطوة من خطوات الذكاء الاصطناعي — من خرج softmax (متعدد الحدود)، إلى ضوضاء التدريب (غاوسي)، إلى زمن وصول الطلبات (أسّي)، إلى عدد الأحداث النادرة (بواسون). معرفة هذه التوزيعات تتيح:

- اختيار **شرط مسبق (prior)** ودالّة **احتمالية (likelihood)** صحيحين؛
- فهم خسائر مثل الإنتروبيا المتقاطعة والـ L1/L2؛
- تحليل تقارب المُحسِّنات والتحقّق من فرضيات إحصائية.

خريطة الفصل

القسم	المحتوى	النظرية/القانون
2.14	التوزيعات المنفصلة القياسية	كتلة الاحتمال (1.14)
3.14	التوزيعات المستمرة القياسية	الكثافة الغاوسية (2.14)
4.14	المشتركة، التهميش، وجمع المتغيرات	التهميش والالتفاف (3.14)
5.14	تحويل المتغيرات وقاعدة الجاكوبي	تغيير المتغيرات (4.14)
6.14	التوزيع الغاوسي متعدّد المتغيرات	كثافة MVN (5.14)
7.14	الدوال المولّدة للحظات والمميّزة	MGF وجمع المستقلّة (6.14)

التعريف

dir="ltr"> <div

a in values takes X RV discrete A **variable). random (Discrete 1.2.14 Definition**
satisfying ,$p_X(k) = \mathbb{P}(X = k)$ **function mass probability** with $\mathcal{X} \subseteq \mathbb{R}$ set countable
.$\sum_{k \in \mathcal{X}} p_X(k) = 1$ and $p_X(k) \geq 0$

families: Standard

- **Bernoulli(**p**):** $\mathbb{P}(X = 1) = p,\ \mathbb{P}(X = 0) = 1 - p$.
- **Binomial(**n, p**):** independent $X = \sum_{i=1}^{n}$ Bernoulli(p); counts successes in n trials.
- **Poisson(**λ**):** rare-event models; as Binomial of limit counts $n \to \infty,\ np \to \lambda$.
- **Geometric(**p**):** trials until first success; memoryless on $\{1, 2, \dots\}$.
- **Multinomial: / Categorical** multi-class generalization.

$$P(X=k)=\binom{n}{k}p^k(1-p)^{n-k},\qquad k=0,1,\dots,n. \tag{1.14}$$

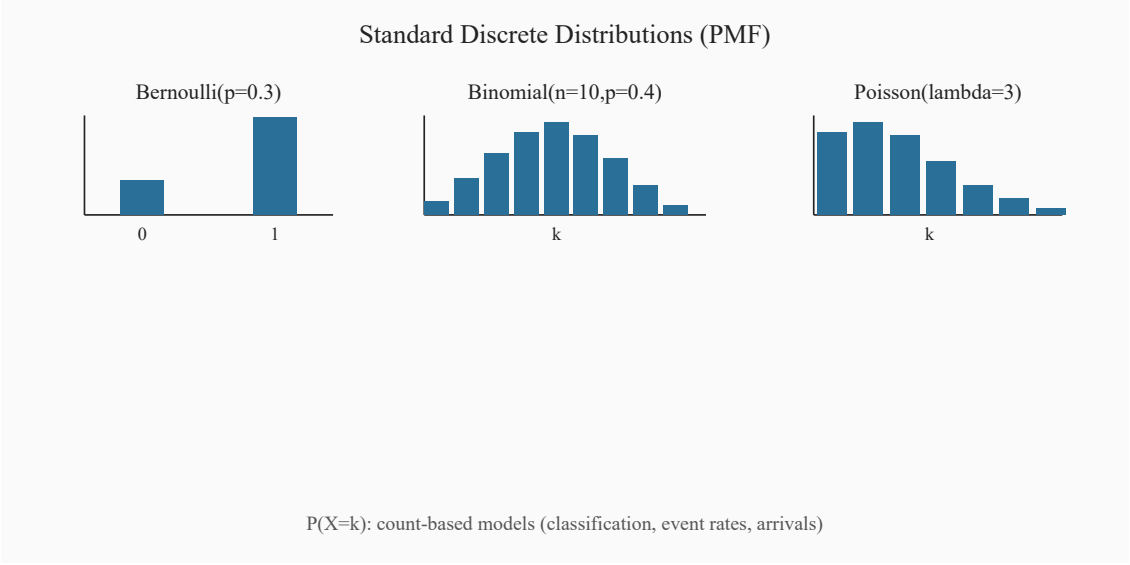
dir="ltr"> <div
k of likelihood the is it models: count of workhorse the is (1.14) PMF Binomial The
its are Geometric and Poisson draws. Bernoulli independent n of out outcomes "positive"
regimes. sampling dffierent for siblings

جدول الرموز

الرمز	الاسم	المعنى
$p_X(k)$	كتلة الاحتمال	$\mathbb{P}(X=k)$
n	عدد التجارب	في ذي الحدّين
p	احتمال النجاح	معلمة برنولي/ذي الحدّين
λ	المعدّل	متوسّط بواسون
$\binom{n}{k}$	المُعامل الثنائي	عدد الترتيبات

رسم توضيحي

<figure> الشكل<figcaption> 1.14: كُتَل الاحتمال للمتغيرات المنفصلة القياسية. برنولي يصف تجربةً واحدة، ذو



شكل ١٠١٤: *
توزيعات منفصلة قياسية

الحدّين يجمع n تجربة، بواسون يصف الأحداث النادرة. كلها نماذج «عدّ» تظهر في التصنيف والكشف.</figcaption>
</figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط ذي الحدّين بواسون	بواسون حدّ لـ n كبير	استخدم بواسون للأحداث النادرة
نسيان $\sum p = 1$	يبطل التوزيع	دائماً تحقّق المجموع
اعتبار البرنولي مستمراً	قيمتاه 0/1 فقط	هو منفصل بحت

أمثلة محلولة على التوزيعات المنفصلة (15 مثالاً)

مثال (1-2.14).

احتمال صنف واحد صحيح في تصنيف ثنائي. المعطيات: نموذج دقّته $p = 0.85$ على عيّنة واحدة. المطلوب: احسب $\mathbb{P}$(صحيح) و$\mathbb{P}$(خاطئ). الحل: الخطوة 1: النموذج برنولي $X \sim \text{Bern}(0.85)$ حيث $X = 1$ يعني صحيح. الخطوة 2: $\mathbb{P}(X = 1) = p = 0.85$، و$\mathbb{P}(X = 0) = 1 - p = 0.15$. النتيجة: الصحّة 85.0 والخطأ 15.0. الربط بالذكاء الاصطناعي: خرج softmax مُقسّر إلى برنولي هو أساس التصنيف الثنائي والعتبة 5.0.

مثال (2-2.14).

عدد الصور المصنّفة صحيحاً من بين 20 صورة. المعطيات: $n = 20$، $p = 0.9$. المطلوب: $\mathbb{P}(X = 18)$ حيث $X \sim \text{Bin}(20, 0.9)$. الحل: الخطوة 1: نطبّق (1.14): $\binom{20}{18} 0.9^{18} 0.1^2$. الخطوة 2: $\binom{20}{18} = 190$، و$0.9^{18} \approx 0.1658$، و$0.1^2 = 0.01$. الخطوة 3: $190 \times 0.1658 \times 0.01 \approx 0.315$. النتيجة: $\mathbb{P}(X = 18) \approx 0.315$. الربط بالذكاء الاصطناعي: تقدير دقّة نموذج على دفعة (batch) كتوزيع ذي حدّين.

مثال (3-2.14).

قناع التسرب (Dropout) — عدد الوحدات النشطة. المعطيات: طبقة فيها $n = 1024$ وحدة، احتمال الإبقاء $p = 0.5$. المطلوب: المُتوسّط و600أكثر من)$\mathbb{P}$ نشطة). الحل: الخطوة 1: $X \sim \text{Bin}(1024, 0.5)$، ف $\mathbb{E}[X] = np = 512$. الخطوة 2: باختصار التقارب نقاربها غاوسياً، 600 تبعد $(600 - 512)/\sqrt{256} \approx 5.5$ انحراف معياري $\rightarrow$ احتمال ضئيل جداً. النتيجة: المُتوسّط 512؛ احتمال <600 نشطة شبه منعدم. الربط بالذكاء الاصطناعي: دروب-آوت يجعل كل تمريرة شبكةً عشوائية؛ العدد النشط يتبع ذا الحدّين.

مثال (4-2.14).

عدد الطلبات الواردة لخادم في الثانية. المعطيات: المعدّل $\lambda = 5$ طلب/ثانية. المطلوب: $\mathbb{P}(X = 3)$ حيث $X \sim \text{Pois}(5)$. الحل: الخطوة 1: $P(X = 3) = e^{-5} 5^3 / 3!$. الخطوة 2: $e^{-5} \approx 0.00674$، $5^3 = 125$، $3! = 6$. الخطوة 3: $0.00674 \times 125/6 \approx 0.1404$. النتيجة: ≈ 0.140. الربط بالذكاء الاصطناعي: نمذجة أحمال API وضبط المُقياس (autoscaling) عبر بواسون.

مثال (14.2-5).

عدد الإنذارات الخاطئة يومياً في نظام أمني. المعطيات: متوسّط $\lambda = 2$ إنذار/يوم. المطلوب: احتمال ألاّ يحدث إنذار ($\mathbb{P}(X = 0)$). الحل: الخطوة 1: $P(X = 0) = e^{-2}2^0/0! = e^{-2}$. الخطوة 2: $e^{-2} \approx 0.1353$. النتيجة: $\approx 13.5\%$. الربط بالذكاء الاصطناعي: حدّد عتبة الإنذار بمقارنة معدّل خطأ الأساس (baseline) البواسوني.

مثال (14.2-6).

عدد خطوات التدرّج حتى أول تقارب. المعطيات: احتمال نجاح كل خطوة $p = 0.1$. المطلوب: $\mathbb{P}(k = 5)$ التقارب في بالضبط خطوة)، $X \sim \text{Geom}(0.1)$. الحل: الخطوة 1: $P(X = 5) = (1-p)^4 p =$ $0.9^4 \times 0.1$. الخطوة 2: $0.9^4 = 0.6561$، فـ 0.06561. النتيجة: $\approx 6.56\%$. الربط بالذكاء الاصطناعي: تحليل زمن الوصول لهذه الخوارزمية قبل التقارب (time-to-convergence).

مثال (14.2-7).

أول نقرة مستخدم في حملة إعلانية. المعطيات: معدّل نقر $p = 0.02$. المطلوب: المُتوسّط حتى أول نقرة $\mathbb{E}[X]$. الحل: الخطوة 1: للهندسي $\mathbb{E}[X] = 1/p$. الخطوة 2: $1/0.02 = 50$. النتيجة: 50 ظهوراً في المُتوسّط. الربط بالذكاء الاصطناعي: تقدير تكلفة الاستحواذ (CPA) من معدّل النقر.

مثال (14.2-8).

أخذ عيّنة من فئة عبر softmax. المعطيات: softmax يُعطي $[0.1, 0.6, 0.3]$ لثلاث فئات. المطلوب: احتمال اختيار الفئة 2. الحل: الخطوة 1: التوزيع الفئوي (Categorical) $p = [0.1, 0.6, 0.3]$، والمجموع 1. الخطوة 2: $\mathbb{P}(Y = 2) = p_2 = 0.6$. النتيجة: 0.6. الربط بالذكاء الاصطناعي: «أخذ عيّنة» (sampling) من softmax لتوليد نصّ أو عمل عشوائي.

مثال (14.2-9).

توزيع كلمات في مستند (متعدّد الحدود). المعطيات: حجم المستند $n = 100$ كلمة، احتمالات 3 كلمات $[0.5, 0.3, 0.2]$. المطلوب: احتمال ظهور الكلمة الأولى 55 مرّة. الحل: الخطوة 1: متعدّد الحدود: $P(\mathbf{k}) = \frac{n!}{k_1!k_2!k_3!} p_1^{k_1} p_2^{k_2} p_3^{k_3}$. الخطوة 2: بـ $k_1 = 55$، نحتاج $k_2 + k_3 = 45$؛ نأخذ مثالاً بـ $k_2 = 30, k_3 = 15$. الخطوة 3: المعامل $\frac{100!}{55!30!15!}$ ضخم، لكن نسبته تُحسب لوغاريتمياً في Bayes. Naive النتيجة: الشكل العام متعدّد الحدود. الربط بالذكاء الاصطناعي: نموذج كيس الكلمات (Bag-of-Words) وBayes. Naive

مثال (14.2-10).

عدد الإخفاقات قبل التحويل الخامس. المعطيات: معدّل تحويل $p = 0.25$، نريد $r = 5$ نجاحات. المطلوب: $\mathbb{P}(X = 12)$ حيث $X \sim \text{NegBin}(5, 0.25)$ (إخفاقات قبل النجاح الخامس). الحل: الخطوة 1: $P(X =$

$\binom{12+5-1}{5-1}p^5(1-p)^{12} = \binom{16}{4}0.25^5 0.75^{12}$، $\binom{16}{4} = 1820$ الخطوة 2: 12. $0.25^5 \approx 0.000977$، $0.75^{12} \approx 0.0317$ الخطوة 3: $0.00564 \approx 0.0317 \times 0.000977 \times 1820$. النتيجة: $\approx 0.56\%$. الربط بالذكاء الاصطناعي: نمذجة «عدد المحاولات حتى الهدف» في تعزيز التعلّم.

مثال (11-2.14).

احتمال k رؤوس في n رمية عملة. المعطيات: عملة عادلة $p = 0.5$، $n = 10$. المطلوب: $\mathbb{P}(X = 5)$. الحل: الخطوة 1: $\binom{10}{5}0.5^{10} = 252/1024$. الخطوة 2: $0.246 \approx 252/1024$. النتيجة: $\approx 24.6\%$. الربط بالذكاء الاصطناعي: اختبار توزيع محتوى التوليد (هل المُولِّد «عادل»؟).

مثال (12-2.14).

اشتقاق بواسون كحدّ لذي الحدّين. المعطيات: $X_n \sim \text{Bin}(n, p_n)$ مع $np_n = \lambda$ ثابت، $n \to \infty$. المطلوب: أثبت أن $\mathbb{P}(X_n = k) \to e^{-\lambda}\lambda^k/k!$. الحل: الخطوة 1: $\binom{n}{k}p_n^k(1-p_n)^{n-k} = \frac{n(n-1)\cdots(n-k+1)}{k!}(\lambda/n)^k(1-\lambda/n)^n(1-\lambda/n)^{-k}$. الخطوة 2: الحدّ الأول $\to 1$، $(1-\lambda/n)^n \to e^{-\lambda}$، والباقي $\to 1$. النتيجة: يؤول إلى كتلة بواسون. الربط بالذكاء الاصطناعي: عند تصغير احتمال كل حدث وزيادة عددها (ضوضاء نادرة) يظهر بواسون طبيعياً.

مثال (13-2.14).

حساب المُتوسّط لذي الحدّين عبر كتلة الاحتمال. المعطيات: $X \sim \text{Bin}(n, p)$. المطلوب: أثبت $\mathbb{E}[X] = np$. الحل: الخطوة 1: $\mathbb{E}[X] = \sum_{k=0}^{n} k\binom{n}{k}p^k(1-p)^{n-k}$. الخطوة 2: نكتب $k\binom{n}{k} = n\binom{n-1}{k-1}$ ونعيد القياس بـ p لنحصل على $np\sum\binom{n-1}{j}p^j(1-p)^{n-1-j} = np$. النتيجة: $\mathbb{E}[X] = np$. الربط بالذكاء الاصطناعي: توقّع عدد التصنيفات الصحيحة = دقّة × حجم الدفعة.

مثال (14-2.14).

تباين بواسون. المعطيات: $X \sim \text{Pois}(\lambda)$. المطلوب: أوجد $\text{Var}(X)$. الحل: الخطوة 1: $\mathbb{E}[X] = \lambda$، و$\mathbb{E}[X(X-1)] = \sum k(k-1)e^{-\lambda}\lambda^k/k! = \lambda^2$. الخطوة 2: $\mathbb{E}[X^2] = \lambda^2 + \lambda$، فـ $\text{Var} = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \lambda$. النتيجة: $\text{Var}(X) = \lambda$ (يساوي المُتوسّط). الربط بالذكاء الاصطناعي: في بواسون المُتوسّط=التباين؛ انحراف ذلك يدلّ على «تشتّت زائد» (overdispersion) في البيانات.

مثال (15-2.14).

إنتروبيا برنولي. المعطيات: $X \sim \text{Bern}(p)$. المطلوب: أوجد الإنتروبيا $H(X) = -p\log p - (1-p)\log(1-p)$ وقيمتها عند $p = 0.5$. الحل: الخطوة 1: $H = -\sum p_i \log p_i = -p\log p - (1-p)\log(1-p)$. الخطوة 2: عند $p = 0.5$: $-0.5\log 0.5 - 0.5\log 0.5 = \log 2 \approx 0.693$ (بتّ). النتيجة: الإنتروبيا العظمى 1 بت عند $p = 0.5$. الربط بالذكاء الاصطناعي: خسارة الإنتروبيا المتقاطعة تستند إلى هذه الإنتروبيا؛ $p = 0.5$ أعلى شكّاً.

التعريف

dir="ltr"> <div

Definition 1.3.14 (Continuous random variable). A continuous RV X has **probability density function** $f_X(x)$ with $f_X(x) \geq 0$ and $\int_{\mathbb{R}} f_X(x)\,dx = 1$. **Standard families:**

- **Uniform(a, b):** flat on $[a, b]$.
- **Exponential(λ):** memoryless waiting times; on $[0, \infty)$.
- **Normal(μ, σ^2):** bell curve; limit/sum of many RVs.
- **Laplace(b):** double exponential; heavy tails $\Rightarrow$ L1 prior.
- **Beta: / Gamma** rates for priors conjugate probabilities.
- **Chi-squared(k):** k standard normals squared sum of

$$f(x) = \frac{1}{\sqrt{2\pi}\,\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \tag{2.14}$$

dir="ltr"> <div

(2.14) density Gaussian The is it law: continuous important most single the is
(CLT), sums of shape stationary/typical the in prior the GPs in and VAEs, in model noise the and regression.

جدول الرموز

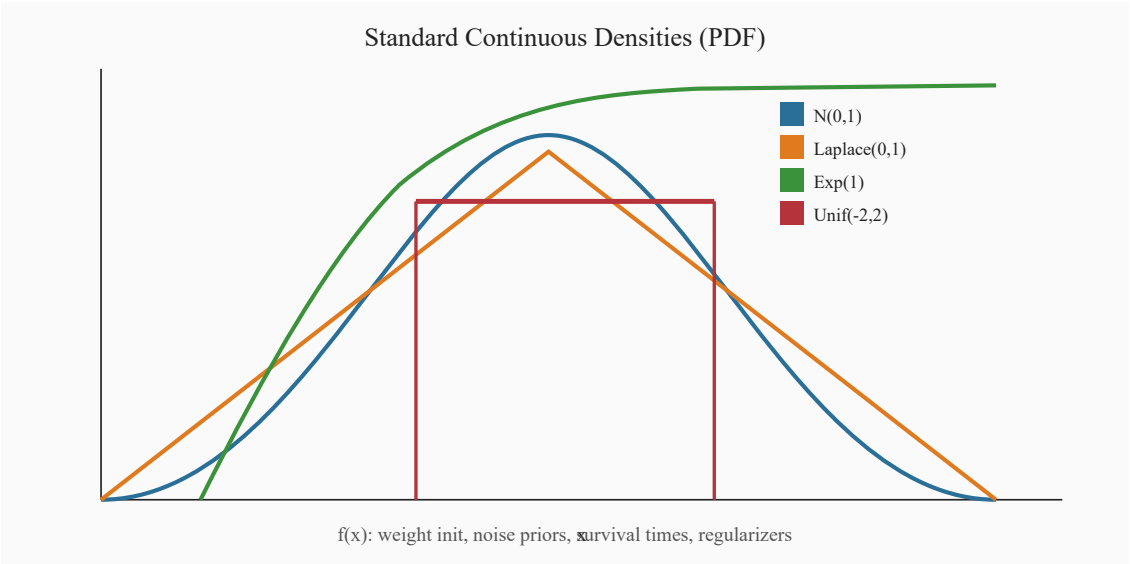
الرمز	الاسم	المعنى
$f_X(x)$	كثافة الاحتمال	مشتقّ التوزيع التراكمي
μ	المُتوسّط	مركز الغاوسي
σ^2	التباين	اتّساع الغاوسي
λ	المعدّل	أسّي/بواسون
$\Gamma(\alpha)$	دالّة غاما	معمّمة للمضروب

رسم توضيحي

<figure> الشكل 2.14: الكثافات القياسية. الغاوسي (أزرق) متماثل؛ لابلاس (برتقالي) ذو قمة حادّة وذيول ثقيلة؛ الأسّي (أخضر) متناقص أُسّياً؛ المنتظم (أحمر) مسطّح. تُستخدم كلها كضوضاء أو كشروط مسبقة.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
قياس $f(x)$ كاحتمال	الكثافة ليست احتمالاً	الاحتمال = تكامل
نسيان $\int f = 1$	يبطل التوزيع	تحقّق التطبيع
الخلط بين σ وσ^2	الأولى انحراف معياري	وثّق الوحدة



شكل ٢٠١٤: *
توزيعات مستمرة قياسية

أمثلة محلولة على التوزيعات المستمرة (15 مثالاً)

مثال (1-3.14).

تهيئة أوزان منتظمة. المعطيات: $W \sim \text{Unfi}(-0.1, 0.1)$. المطلوب: $\mathbb{P}(|W| < 0.05)$ والمُتوسّط. الحل: الخطوة 1: الكثافة $1/(0.2) = 5$ على $[-0.1, 0.1]$. الخطوة 2: $\mathbb{P}(|W| < 0.05) = \int_{-0.05}^{0.05} 5\, dw = 0.5 \times 0.1 = 0.5$. الخطوة 3: المُتوسّط $(a+b)/2 = 0$. النتيجة: الاحتمال 50% والمُتوسّط 0. الربط بالذكاء الاصطناعي: التهيئة المنتظمة (unfiorm init) القديمة، تمنع الأوزان الصفرية لكنها ضعيفة للشبكات العميقة.

مثال (2-3.14).

اختيار بذرة عشوائية من فترة. المعطيات: $U \sim \text{Unfi}(0, 1)$، نريد قيمة < 0.2. المطلوب: الاحتمال. الحل: الخطوة 1: للمنتظم $\mathbb{P}(U < c) = c$. الخطوة 2: $\mathbb{P}(U < 0.2) = 0.2$. النتيجة: 20%. الربط بالذكاء الاصطناعي: مولّدات الأرقام الكاذبة العشوائية (PRNG) تُنتج $U(0, 1)$ ثم نُحوّلها.

مثال (3-3.14).

الزمن بين طلبين لـ API. المعطيات: $T \sim \text{Exp}(\lambda = 2)$ (طلب/ثانية). المطلوب: $\mathbb{P}(T > 1)$ والمُتوسّط. الحل: الخطوة 1: $P(T > t) = e^{-\lambda t} = e^{-2}$. الخطوة 2: $e^{-2} \approx 0.135$، المُتوسّط $1/\lambda = 0.5$ ثانية. النتيجة: احتمال التجاوز $\approx 13.5\%$، المُتوسّط 0.5 ث. الربط بالذكاء الاصطناعي: نمذجة زمن الاستجابة وضبط مهلة (timeout) الخدمة.

مثال (14.3-4).

خاصيّة انعدام الذاكرة للأسّي. المعطيات: $T \sim \text{Exp}(\lambda)$، مضى زمن s دون حدث. المطلوب: أثبت $\mathbb{P}(T > s+t \mid T > s) = \mathbb{P}(T > t)$. الحل: الخطوة 1: $\mathbb{P}(T > s+t \mid T > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(T > t)$. النتيجة: لا تتأثّر بالزمن المنقضي. الربط بالذكاء الاصطناعي: في طوابير الخدمات (M/M/1) الانتظار المتبقي موزّع أسّياً مهما مضى.

مثال (14.3-5).

خلايا ميتة (تشبّع) في التنشيط. المعطيات: $Z \sim \mathcal{N}(0,1)$ قبل التنشيط، نريد $\mathbb{P}(Z > 2)$. المطلوب: احسبها بالتقريب. الحل: الخطوة 1: من جدول التوزيع التراكمي القياسي $\Phi(2) \approx 0.9772$. الخطوة 2: $\mathbb{P}(Z > 2) = 1 - 0.9772 = 0.0228$. النتيجة: $\approx 2.3\%$. الربط بالذكاء الاصطناعي: نسبة الخلايا المشبّعة (dead ReLU) ترتبط بانحراف المعاملات عن الصفر.

مثال (14.3-6).

احتمال بُعد الوزن عن مركزه. المعطيات: $W \sim \mathcal{N}(0, \sigma^2)$، $\sigma = 0.05$. المطلوب: $\mathbb{P}(|W| > 2\sigma)$. الحل: الخطوة 1: $Z = W/\sigma \sim \mathcal{N}(0,1)$، فنريد $\mathbb{P}(|Z| > 2) = 2(1 - \Phi(2))$. الخطوة 2: $2 \times 0.0228 = 0.0456$. النتيجة: $\approx 4.6\%$. الربط بالذكاء الاصطناعي: قاعدة 2σ لتشخيص الأوزان الشاذة أثناء التدريب.

مثال (14.3-7).

قاعدة 68–95–99.7. المعطيات: $X \sim \mathcal{N}(\mu, \sigma^2)$. المطلوب: نسب البيانات ضمن $k = 1, 2, 3$ انحراف معياري. الحل: الخطوة 1: $\mathbb{P}(|X - \mu| < k\sigma) = \Phi(k) - \Phi(-k) = 2\Phi(k) - 1$. الخطوة 2: لـ $k = 1, 2, 3$: $0.682, 0.954, 0.997$. النتيجة: 68%، 95%، 99.7%. الربط بالذكاء الاصطناعي: كشف الشذوذ (anomaly) عند تجاوز 3σ في ميزات الموثوقية.

مثال (14.3-8).

شرط مسبق L1 (لابلاس). المعطيات: $W \sim \text{Laplace}(0, b = 1)$. المطلوب: الكثافة عند $w = 0$ و$\mathbb{P}(|W| > 2)$. الحل: الخطوة 1: $f(0) = \frac{1}{2b}e^0 = 0.5$. الخطوة 2: $P(|W| > 2) = e^{-2/1} = e^{-2} \approx 0.135$. النتيجة: $f(0) = 0.5$، الذيل 13.5%. الربط بالذكاء الاصطناعي: شرط L1 المسبق يعاقب الأوزان الصغيرة أكثر $\rightarrow$ تناثر، (sparsity) أساس الـ Lasso.

مثال (14.3-9).

شرط مسبق مترافق لمعدّل بواسون. المعطيات: $\lambda \sim \text{Gamma}(\alpha = 2, \beta = 1)$، لاحظ $X \mid \lambda \sim \text{Pois}(\lambda)$. المطلوب: صياغة الشرط المسبق وتحقّق التطبيع على $[0, \infty)$. الحل: الخطوة 1: $f(\lambda) = \frac{\beta^\alpha}{\Gamma(\alpha)}\lambda^{\alpha-1}e^{-\beta\lambda} = \frac{1}{1}\lambda e^{-\lambda}$. الخطوة 2: $\int_0^\infty \lambda e^{-\lambda} d\lambda = \Gamma(2) = 1$ ✓. النتيجة: كثافة مترافقة صحيحة. الربط بالذكاء الاصطناعي: بايز سوى (empirical Bayes) يستخدم غاما كشرط مسبق لمعدّلات الأحداث.

مثال (3.14-10).

شرط مسبق لاحتمال برنولي. المعطيات: $p \sim \text{Beta}(\alpha = 2, \beta = 2)$. المطلوب: الكثافة عند $p = 0.5$ وحيث تُمركز. الحل: الخطوة 1: $f(p) = \frac{p(1-p)}{B(2,2)}$، و$B(2,2) = \frac{\Gamma 2 \Gamma 2}{\Gamma 4} = \frac{1}{6}$. الخطوة 2: $f(0.5) = 0.25 \times 6 = 1.5$، القمة عند $p = 0.5$. النتيجة: متماثل حول 5.0. الربط بالذكاء الاصطناعي: بيتا مترافق مع برنولي؛ يُحدّث بعد كل ملاحظة بزيادة α أو β.

مثال (3.14-11).

كشف شذوذ بمربّع كاي. المعطيات: $Q = \sum_{i=1}^{k} Z_i^2$، $Z_i \sim \mathcal{N}(0,1)$ مستقلّة، $k = 3$. المطلوب: $\mathbb{P}(Q > \chi^2_{0.95,3})$ تقريباً. الحل: الخطوة 1: $Q \sim \chi^2_3$، والنسبة المئوية 95% تقريباً 7.81. الخطوة 2: القيمة المرصودة >81.7 تقع في الذيل 5%. النتيجة: إنذار شذوذ عند تجاوز 81.7. الربط بالذكاء الاصطناعي: مسافة ماهالانوبيس المُربّعة تتبع χ^2_k تحت الفرضية الغاوسية.

مثال (3.14-12).

تحليل بقاء نموذج. المعطيات: زمن عطل الخدمة $T \sim \text{Exp}(\lambda = 0.01)$ (ساعة$^{-1}$). المطلوب: احتمال البقاء ساعةً إضافية بعد 50 ساعة. الحل: الخطوة 1: بالانعدام الذاكرة $P(T > 51 \mid T > 50) = P(T > 1) = e^{-0.01}$. الخطوة 2: ≈ 0.99. النتيجة: 99% تقريباً. الربط بالذكاء الاصطناعي: نماذج البقاء (survival models) في صيانة تنبّؤية.

مثال (3.14-13).

توزيع لوغ-نورمال لأحجام الملفات. المعطيات: $\log S \sim \mathcal{N}(0,1)$، نريد $\mathbb{P}(S > e^2)$. المطلوب: احسبها. الحل: الخطوة 1: $\log S > 2 \iff S > e^2$. الخطوة 2: $\mathbb{P}(\log S > 2) = 1 - \Phi(2) \approx 0.0228$. النتيجة: $\approx 2.3\%$. الربط بالذكاء الاصطناعي: أحجام الطلبات/الملفات لوغ-نورمالية؛ مهمّة لتقدير السعة.

مثال (3.14-14).

اختبار z لعيّنتين. المعطيات: فرق المُتوسّطات $\bar{X}_1 - \bar{X}_2 = 0.4$، الانحراف المعياري للفرق 2.0. المطلوب: القيمة-z واحتمال الذيل. الحل: الخطوة 1: $z = 0.4/0.2 = 2$. الخطوة 2: $P(|Z| > 2) \approx 0.0456$ (من 6-3.14). النتيجة: ذيل 4.56% (دالّ على فرق معنوي عند 5%). الربط بالذكاء الاصطناعي: اختبار أهمّية تغيير في دقّة نموذجين.

مثال (3.14-15).

تقييم مكوّن GMM. المعطيات: مكوّن غاوسي $f_k(x)$ بوزن $\pi_k = 0.3$. المطلوب: مساهمة المكوّن في الكثافة الكلّية عند نقطة. الحل: الخطوة 1: $f(x) = \sum_k \pi_k \mathcal{N}(x; \mu_k, \sigma_k^2)$، مساهمة هذا المكوّن $\pi_k f_k(x)$. الخطوة 2: إن كانت $f_k(x) = 0.4$ فالمساهمة $0.3 \times 0.4 = 0.12$. النتيجة: 12.0. الربط بالذكاء الاصطناعي: نماذج الخليط

الغاوسي (GMM) لتجميع البيانات (clustering).

التعريف

dir="ltr"> <div

Definition (Joint 1.4.14). The RVs X, Y have **joint** PMF/PDF $f_{X,Y}$ if it satisfies $\sum_{x,y} f = 1$ (discrete) or $\iint f\,dx\,dy = 1$ (continuous). The **marginal** is obtained by summing/integrating the other variable. **Independence** means $f_{X,Y} = f_X f_Y$. The density of a sum of independent RVs is their **convolution**.

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x,y)\,dy; \qquad f_{X+Y}(z) = \int_{\mathbb{R}} f_X(x) f_Y(z-x)\,dx. \tag{3.14}$$

dir="ltr"> <div

Equation (3.14) is the workhorse of inference: to marginalize a variable, one integrates out the other, and to convolve independent noise sources, one combines evidence, given to infer condition.

جدول الرموز

الرمز	الاسم	المعنى
$f_{X,Y}$	كثافة مشتركة	توزيع الاثنين معاً
f_X	كثافة هامشية	بعد تهميش Y
$\perp\!\!\!\perp$	استقلال	$f_{X,Y} = f_X f_Y$
$*$	التفاف	جمع المتغيرات المستقلّة

رسم توضيحي

<figure> الشكل<figcaption> 3.14: الكثافة المشتركة $f_{X,Y}$ (يسار)، والهامشيات الناتجة بتهميش المتغير الآخر (أسفل/يسار). الاستقلال يُفكّك المشترك إلى جداء الهامشيات.</figcaption> </figure>

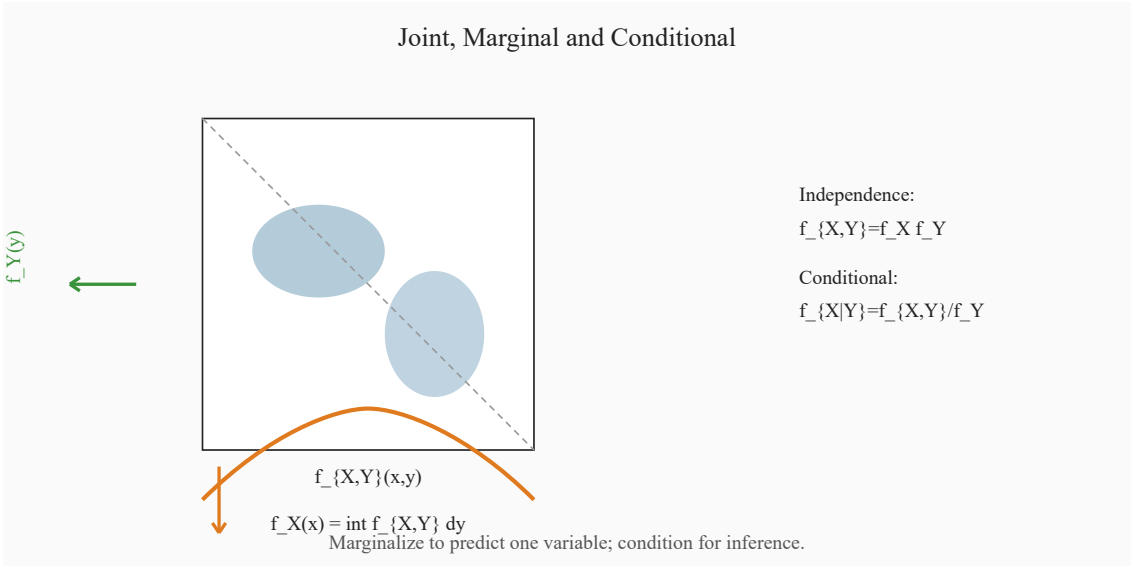
أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اعتبار التهميش جمعاً بسيطاً	هو تكامل/جمع على الآخر	استخدم (3.14)
افتراض الاستقلال تلقائياً	كثير من المتغيرات مترابطة	تحقّق من الجداء
خلط المشترك بالهامشي	يختلفان جذرياً	فرّق الرموز

أمثلة محلولة على المشترك والتهميش والجمع (15 مثالاً)

مثال (1-4.14).

جدول احتمالات مشتركة لخاصيّتين. المعطيات: $X, Y \in \{0,1\}$، $P(0,0) = 0.4, P(0,1) = 0.1, P(1,0) = 0.2, P(1,1) = 0.3$. المطلوب: هامش Y لإيجاد $P(X=1)$. الحل: الخطوة 1: $P(X=1) = P(1,0) + P(1,1) = 0.2 + 0.3$. الخطوة 2: $= 0.5$. النتيجة: $P(X=1) = 0.5$. الربط بالذكاء



شكل ٣.١٤: *
توزيع مشترك وتهميش

الاصطناعي: جداول الاحتمالات المشتركة في الشبكات البايزية البسيطة.

مثال (2-4.14).

تهميش كثافة مستمرة. المعطيات: $f_{X,Y}(x,y) = 2e^{-x-y}$ على $0 < x < y < \infty$. المطلوب: $f_X(x)$. الحل: الخطوة 1: $f_X(x) = \int_x^\infty 2e^{-x-y}dy = 2e^{-x}[-e^{-y}]_x^\infty = 2e^{-2x}$، $x > 0$. النتيجة: $f_X(x) = 2e^{-2x}$. الربط بالذكاء الاصطناعي: استخراج توزيع ميزة من نموذج مشترك للميزات.

مثال (3-4.14).

فحص الاستقلال من جدول. المعطيات: نفس جدول (1-4.14). المطلوب: هل $X \perp Y$؟ الحل: الخطوة 1: $P(X=1) = 0.5$، $P(Y=1) = 0.1 + 0.3 = 0.4$. الخطوة 2: $P(X=1, Y=1) = 0.3$ لكن $P(X=1)P(Y=1) = 0.5 \times 0.4 = 0.2 \neq 0.3$. النتيجة: غير مستقلّين. الربط بالذكاء الاصطناعي: كشف ارتباط الميزات قبل التدريب يتجنّب تعدّد الخطية.

مثال (4-4.14).

مجموع برنوليَّيْن $\rightarrow$ ذو الحدّين. المعطيات: X, Y برنولي(p) مستقلّان، $S = X + Y$. المطلوب: أوجد توزيع S. الحل: الخطوة 1: $S \in \{0, 1, 2\}$، $P(S=0) = (1-p)^2$، $P(S=2) = p^2$، $P(S=1) = 2p(1-p)$. الخطوة 2: هذا ذو حدّين $\text{Bin}(2,p)$. النتيجة: $\text{Bin}(2,p)$ (حالة خاصة من الالتفاف). الربط بالذكاء الاصطناعي: مجموع عيّنات دروب-آوت يتبع ذا الحدّين (انظر 3-2.14).

مثال (14.4-5).

مجموع بواسون مستقلّين. المعطيات: $X \sim \text{Pois}(\lambda_1)$، $Y \sim \text{Pois}(\lambda_2)$ مستقلّان. المطلوب: أوجد توزيع $X+Y$. الحل: الخطوة 1: $P(X+Y=k) = \sum_{i=0}^{k} e^{-\lambda_1}\frac{\lambda_1^i}{i!}e^{-\lambda_2}\frac{\lambda_2^{k-i}}{(k-i)!} = e^{-(\lambda_1+\lambda_2)}\frac{(\lambda_1+\lambda_2)^k}{k!}$. الخطوة 2: بقانون ذي الحدّين. النتيجة: $\text{Pois}(\lambda_1+\lambda_2)$. الربط بالذكاء الاصطناعي: دمج عدّادَي أحداث من خدمتين يعطي بواسون بمجموع المعدّلات.

مثال (14.4-6).

مجموع غاوسيَّيْن مستقلّين. المعطيات: $X \sim \mathcal{N}(\mu_1,\sigma_1^2)$، $Y \sim \mathcal{N}(\mu_2,\sigma_2^2)$. المطلوب: توزيع $X+Y$. الحل: الخطوة 1: المُتوسّط $\mu_1+\mu_2$، التباين $\sigma_1^2+\sigma_2^2$ (التباينات تُجمع للمستقلّين). الخطوة 2: $X+Y \sim \mathcal{N}(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$. النتيجة: غاوسي بالمجموع. الربط بالذكاء الاصطناعي: ضوضاء المستشعرات المجمّعة تبقى غاوسية؛ أساس تصفية كالمان.

مثال (14.4-7).

مجموع أسّيَّيْن $\to$ غاما (إرلانغ). المعطيات: $X,Y \sim \text{Exp}(\lambda)$ مستقلّان. المطلوب: توزيع $S=X+Y$. الحل: الخطوة 1: التفاف $f_S(s) = \int_0^s \lambda e^{-\lambda x}\lambda e^{-\lambda(s-x)}dx = \lambda^2 s e^{-\lambda s}$. الخطوة 2: هذا غاما$(2,\lambda)$ (إرلانغ الدرجة 2). النتيجة: $\text{Gamma}(2,\lambda)$. الربط بالذكاء الاصطناعي: زمن خدمة طلبين متتاليين (طابور M/M/1 موزّع إرلانغ).

مثال (14.4-8).

التغاير من توزيع مشترك. المعطيات: الجدول في (14.4-1)، مع X,Y قيمهما 0/1. المطلوب: $\text{Cov}(X,Y)$. الحل: الخطوة 1: $\mathbb{E}[XY] = P(1,1) = 0.3$، $\mathbb{E}[X] = 0.5$، $\mathbb{E}[Y] = 0.4$. الخطوة 2: $\text{Cov} = 0.3 - 0.5\times 0.4 = 0.1$. النتيجة: 1.0 (مترابطان إيجابياً). الربط بالذكاء الاصطناعي: مصفوفة التغاير هي أساس PCA وخفض البُعد.

مثال (14.4-9).

معامل الارتباط. المعطيات: نفس الجدول، $\text{Var}(X) = 0.25$، $\text{Var}(Y) = 0.24$. المطلوب: ρ_{XY}. الحل: الخطوة 1: $\rho = 0.1/\sqrt{0.25\times 0.24} = 0.1/\sqrt{0.06} \approx 0.408$. النتيجة: $\rho \approx 0.41$. الربط بالذكاء الاصطناعي: اختيار الميزات بعيدة الارتباط يحسّن استقرار الانحدار.

مثال (14.4-10).

قانون التوقّع التامّ. المعطيات: $\mathbb{E}[X \mid Y=0]=2$، $\mathbb{E}[X \mid Y=1]=5$، $P(Y=0)=0.6$. المطلوب: $\mathbb{E}[X]$. الحل: الخطوة 1: $\mathbb{E}[X] = \sum_y \mathbb{E}[X \mid Y=y]P(Y=y)$. الخطوة 2: $2\times 0.6 + 5\times 0.4 = 1.2+2 = 3.2$. النتيجة: 2.3. الربط بالذكاء الاصطناعي: توقّع الخسارة = متوسّط الخسارة الشرطية على الطبقات

eval). (stratfiied

مثال (14.4-11).

تهميش خليط كامن (latent mixture): $Z \in \{1,2\}$ باحتمال π_1, π_2، و$X \mid Z = k \sim \mathcal{N}(\mu_k, \sigma_k^2)$. المطلوب: الكثافة الهامشية $f_X(x)$. الحل: الخطوة 1: $f_X(x) = \sum_k P(Z = k) f_{X|Z=k}(x) = \pi_1 \mathcal{N}(x; \mu_1, \sigma_1^2) + \pi_2 \mathcal{N}(x; \mu_2, \sigma_2^2)$. النتيجة: خليط غاوسي (GMM) من مكوّنين. الربط بالذكاء الاصطناعي: GMM الكلاسيكي؛ التجميع الناعم (soft assignment).

مثال (14.4-12).

جداء يفكّك المشترك عند الاستقلال. المعطيات: X, Y مستقلّان بكثافتيهما f_X, f_Y. المطلوب: أكّد $f_{X,Y}(x,y) = f_X(x) f_Y(y)$ وأن التهميش يُعطي الأصل. الحل: الخطوة 1: $\int f_X(x) f_Y(y)\, dy = f_X(x) \int f_Y(y) dy$. النتيجة: الهامشية تسترجع f_X. الربط بالذكاء الاصطناعي: في نماذج الاحتمال المولّد نفترض استقلال الميزات (Naive Bayes).

مثال (14.4-13).

التوزيع الشرطي من المشترك. المعطيات: $f_{X,Y}(x,y) = 2e^{-x-y}$ على $0 < x < y$. المطلوب: $f_{X|Y}(x \mid y)$. الحل: الخطوة 1: $f_Y(y) = \int_0^y 2e^{-x-y} dx = 2e^{-y}(1 - e^{-y})$. الخطوة 2: $f_{X|Y} = f_{X,Y} / f_Y = \frac{e^{-x}}{1-e^{-y}}$، $0 < x < y$. النتيجة: شرطي منحنٍ بـ y. الربط بالذكاء الاصطناعي: الاستدلال الشرطي (ملاحظة | سبب) P جوهر بايز.

مثال (14.4-14).

تهميش في بايز ساذج. المعطيات: ميزتان x_1, x_2 مستقلّتان شرطياً، نريد $P(\text{class} \mid x_1, x_2)$. المطلوب: عبّر عن الدليل $P(x_1, x_2)$ المُهمّش. الحل: الخطوة 1: $P(x_1, x_2) = \sum_c P(c) P(x_1 \mid c) P(x_2 \mid c)$ (الاستقلال الشرطي). النتيجة: مجموع على كل الأصناف. الربط بالذكاء الاصطناعي: مُnormalizer في قاعدة بايز لـ Naive Bayes.

مثال (14.4-15).

عقدة في شبكة بايزية. المعطيات: $P(A,B,C) = P(A) P(B \mid A) P(C \mid A,B)$. المطلوب: همّش C لإيجاد $P(A,B)$. الحل: الخطوة 1: $\sum_C P(A,B,C) = \sum_C P(A) P(B \mid A) P(C \mid A,B)$. الخطوة 2: $\sum_C P(C \mid A,B) = 1$، فيبقى $P(A) P(B \mid A) = P(A,B)$. النتيجة: استرجاع المشترك الهامشي. الربط بالذكاء الاصطناعي: خوارزميات التمرير (message passing) تُهمّش العقد الكامنة.

التعريف

dir="ltr"> <div

Definition 1.5.14 (Change of variables). If $Y = g(X)$ with g differentiable monotone, then

$$f_Y(y) = f_X\big(g^{-1}(y)\big)\left|\frac{d}{dy} g^{-1}(y)\right|.$$

In $\mathbf{Y} = \mathbf{g}(\mathbf{X})$ gives dimensions, d

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{x})\left|\det \frac{\partial \mathbf{x}}{\partial \mathbf{y}}\right|, \quad \mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}),$$

the how for accounts it — determinant Jacobian absolute the is factor the where volume. stretches/shrinks

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{x})\left|\det \frac{\partial \mathbf{x}}{\partial \mathbf{y}}\right|, \quad \mathbf{x} = \mathbf{g}^{-1}(\mathbf{y}). \tag{4.14}$$

in change-of-coordinates and flows normalizing makes what is factor Jacobian The moved. naively not preserved, is mass probability correct: inference variational

جدول الرموز

الرمز	الاسم	المعنى
g	دالّة التحويل	$\mathbf{Y} = \mathbf{g}(\mathbf{X})$
J	الجاكوبي	مشتقّة التحويل
$\det$	المحدّد	عامل التمدّد الحجمي
$\lvert\cdot\rvert$	القيمة المطلقة	للحفاظ على الكتلة

رسم توضيحي

<figure>

<figcaption>الشكل 4.14: تحويل $Y = g(X)$. فترة صغيرة dx قد تُمطّ إلى dy أطول؛ عامل $|dy/dx|$ (معكوس محدّد الجاكوبي) يعيد توزيع الكتلة ليبقى المجموع 1.</figcaption>
</figure>

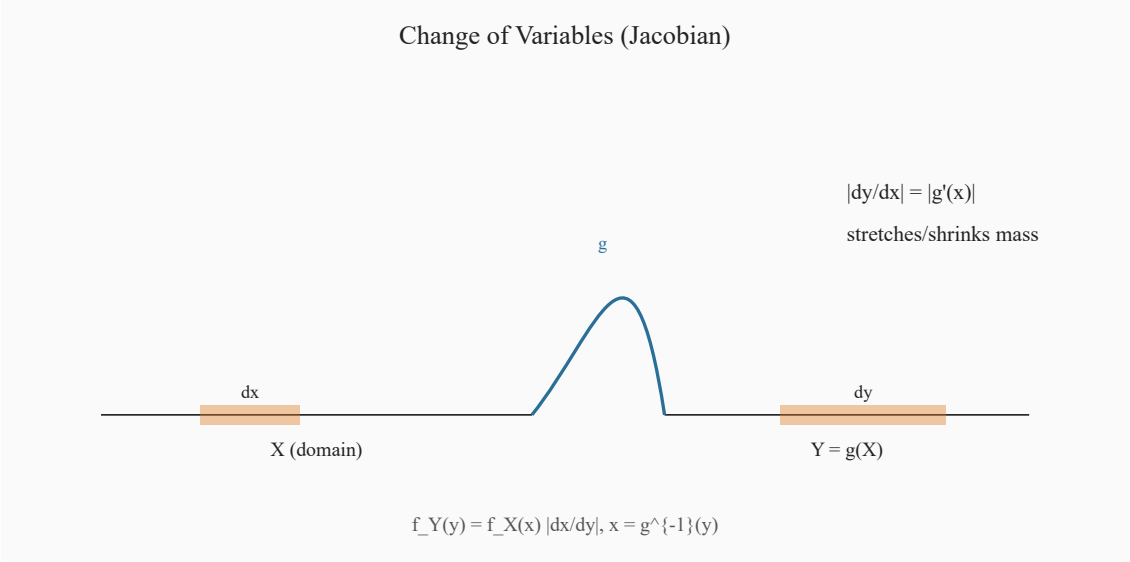
أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
نسيان القيمة المطلقة	الكثافة تُصبح سالبة	خذ $\lvert J\rvert$
إسقاط عامل الجاكوبي	يُبطل التطبيع	اضرب بالمحدّد
خلط الاتجاه $x \to y$	يقلب العامل	استخدم $\partial x/\partial y$

أمثلة محلولة على تحويل المتغيرات (15 مثالاً)

مثال (1-5.14).

تحويل خطّي لغاوسي. المعطيات: $X \sim \mathcal{N}(\mu, \sigma^2)$، $Y = aX + b$، $a \neq 0$. المطلوب: توزيع Y. الحل: الخطوة 1: $x = (y-b)/a$، $dx/dy = 1/a$. الخطوة 2: $f_Y(y) = f_X((y-b)/a) \cdot |1/a|$. الخطوة 3: هذا $\mathcal{N}(a\mu+b, a^2\sigma^2)$. النتيجة: $\frac{1}{|a|\sqrt{2\pi}\sigma}\exp(-\frac{((y-b)/a-\mu)^2}{2\sigma^2})$.



شكل ١٤.٤: *
تغيير المتغيرات والجاكوبي

الربط بالذكاء الاصطناعي: قياس (scaling) الميزات وتحويل الأوزان يحافظان على الغاوسية.

مثال (2-5.14).

تربيع متغيّر معياري $\rightarrow$ كاي^2 واحد. المعطيات: $Z \sim \mathcal{N}(0,1)$، $Y = Z^2$. المطلوب: كثافة Y. الحل: الخطوة 1: Y له فرعان $z = \pm\sqrt{y}$، $dz/dy = 1/(2\sqrt{y})$. الخطوة 2: $f_Y(y) = 2 \cdot \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}$، $y > 0$. النتيجة: χ^2_1. الربط بالذكاء الاصطناعي: إحصاء مربّع كاي لكشف الشذوذ (انظر 14.3-11).

مثال (3-5.14).

تحويل لوغاريتمي (لوغ-نورمال). المعطيات: $X \sim \mathcal{N}(\mu, \sigma^2)$، $Y = e^X$. المطلوب: كثافة Y. الحل: الخطوة 1: $x = \ln y$، $dx/dy = 1/y$. الخطوة 2: $f_Y(y) = \phi(\ln y; \mu, \sigma)/y$، $y > 0$. النتيجة: لوغ-نورمال. الربط بالذكاء الاصطناعي: نمذجة الكميات الموجبة (الأسعار، الأحجام) لوغ-نورمالياً.

مثال (4-5.14).

التوحيد (Standardization). المعطيات: $X \sim \mathcal{N}(\mu, \sigma^2)$. المطلوب: أوجد توزيع $Z = (X - \mu)/\sigma$. الحل: الخطوة 1: $a = 1/\sigma, b = -\mu/\sigma$؛ من (1-5.14) المُتوسّط 0 والتباين 1. النتيجة: $\mathcal{N}(0,1)$. الربط بالذكاء الاصطناعي: توحيد الدُفعات (BatchNorm) يُقرّب هذا لكل دفعة.

مثال (5-5.14).

تحويل السيني للوغيت. المعطيات: لوغيت $z \in \mathbb{R}$، $p = \sigma(z) = 1/(1+e^{-z})$. المطلوب: الجاكوبي dp/dz واستخدامه في اشتقاق الخسارة. الحل: الخطوة 1: $\sigma'(z) = \sigma(z)(1-\sigma(z)) = p(1-p)$. الخطوة 2: في الانتشار العكسي $\partial L/\partial z = (p-y)$ (للإنتروبيا المتقاطعة). النتيجة: المشتقّة $p(1-p)$. الربط بالذكاء الاصطناعي: السيني يربط اللوغيت بالاحتمال؛ جاكوبي يظهر في backprop.

مثال (6-5.14).

تحويل بوكس–كوكس. المعطيات: بيانات موجبة X، تحويل $Y = (X^\lambda - 1)/\lambda$. المطلوب: فكرة الجاكوبي عند $\lambda \to 0$. الحل: الخطوة 1: عند $\lambda \to 0$ يؤول إلى $Y = \ln X$ (اللوغاريتمي). الخطوة 2: نختار λ الذي يجعل Y أقرب للغاوسي. النتيجة: تحويل لجعل البيانات طبيعية. الربط بالذكاء الاصطناعي: معالجة الميزات (feature transform) قبل النماذج الخطية.

مثال (7-5.14).

دوران ثنائي الأبعاد لغاوسي. المعطيات: $\mathbf{X} \sim \mathcal{N}(0, I)$، $\mathbf{Y} = R\mathbf{X}$ بدوران R (مُعامِل 1). المطلوب: تحقّق أن Y غاوسي بنفس التباين. الحل: الخطوة 1: $|\det R| = 1$، فعامل الجاكوبي 1. الخطوة 2: $f_Y(\mathbf{y}) = \phi(\mathbf{y}; 0, I)$. النتيجة: $\mathcal{N}(0, I)$ (محفوظ). الربط بالذكاء الاصطناعي: الدوران/PCA يحافظ على الغاوسية وحدة التباين.

مثال (8-5.14).

إحداثيات قطبية (تحويل إلى r, θ). المعطيات: (X, Y) غاوسي معياري مستقلّ في المستوى. المطلوب: كثافة $R = \sqrt{X^2+Y^2}$. الحل: الخطوة 1: جاكوبي القطبي $|J| = r$؛ $f_{R,\Theta}(r,\theta) = \frac{r}{2\pi} e^{-r^2/2}$. الخطوة 2: تهميش Θ: $f_R(r) = re^{-r^2/2}$ (رويل وايبول/كاي^2 ذيل). النتيجة: نصف القطر يتبع رايلي. الربط بالذكاء الاصطناعي: توزيع اتساع الإشارة في الاتصالات والرؤية.

مثال (9-5.14).

تحويل أفيني لمتعدّد الغاوسي. المعطيات: $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$، $\mathbf{Y} = A\mathbf{X} + \mathbf{b}$. المطلوب: توزيع $\mathbf{Y}$. الحل: الخطوة 1: جاكوبي A^{-1}، محدّده $|A|^{-1}$. الخطوة 2: $\mathbf{Y} \sim \mathcal{N}(A\boldsymbol{\mu} + \mathbf{b}, A\Sigma A^\top)$. النتيجة: غاوسي بالأفيني. الربط بالذكاء الاصطناعي: طبقات خطّية على تمثيلات غاوسية (GP، VAE encoder).

مثال (10-5.14).

معكوس المتغيّر $Y = 1/X$. المعطيات: $X > 0$ بكثافة f_X. المطلوب: كثافة Y. الحل: الخطوة 1: $x = 1/y$، $dx/dy = -1/y^2$. الخطوة 2: $f_Y(y) = f_X(1/y)/y^2$، $y > 0$. النتيجة: معكوس الكثافة مُقاساً بـ y^2. الربط بالذكاء الاصطناعي: نمذجة المعدّلات (عكس الزمن/السرعة).

مثال (11-5.14).

التحويل عبر التوزيع التراكمي (PIT). المعطيات: X بـ CDF F_X صارم التصاعد، $U = F_X(X)$. المطلوب: أثبت $U \sim \text{Unfi}(0,1)$. الحل: الخطوة 1: $F_U(u) = P(F_X(X) \le u) = P(X \le F_X^{-1}(u)) = F_X(F_X^{-1}(u)) = u$. النتيجة: توزيع منتظم. الربط بالذكاء الاصطناعي: طريقة PIT لأخذ عيّنات وأيضاً لاختبار «خذ عيّنة موحّدة».

مثال (12-5.14).

تحويل الكمّية (Quantile transform). المعطيات: X بـ CDF F_X، نريد $Y = \Phi^{-1}(F_X(X))$ (غاوسيّة). المطلوب: توزيع Y. الحل: الخطوة 1: من PIT $F_X(X) \sim U(0,1)$، ثم $\Phi^{-1}(U) \sim \mathcal{N}(0,1)$. النتيجة: $\mathcal{N}(0,1)$. الربط بالذكاء الاصطناعي: Copula و«التوزيع الغاوسي الناتج» في معالجة البيانات.

مثال (13-5.14).

محدّد الجاكوبي لتدفّق عادي (NF). المعطيات: تحويل تآلفي (coupling) $y_1 = x_1$، $y_2 = x_2 e^{s(x_1)} + t(x_1)$. المطلوب: محدّد الجاكوبي. الحل: الخطوة 1: المصفوفة مثلثية، المحدّد $\prod_i \frac{\partial y_i}{\partial x_i} = e^{s(x_1)}$. الخطوة 2: $\log|\det J| = s(x_1)$ (سهل الحساب). النتيجة: لوغاريتم محدّد مغلق الصيغة. الربط بالذكاء الاصطناعي: التدفقات العادية (Normalizing Flows) تعتمد على جاكوبي قطريّ سهل.

مثال (14-5.14).

تحويل بمشتقّة معدومة (لا عكس). المعطيات: $Y = X^3$ عند $x = 0$. المطلوب: هل ينطبق (4.14) عند الصفر؟ الحل: الخطوة 1: المشتقّة $3x^2 = 0$ عند الصفر، لكن $Y = X^3$ عكسها $x = \sqrt[3]{y}$ مستمرّ وكثافتها محدودة. الخطوة 2: القاعدة بصيغتها العامّة (قياس الدفع) لا تشترط مشتقّة معدومة طالما التحويل قابل للعكس a.e. النتيجة: ينطبق تقريباً كلّياً. الربط بالذكاء الاصطناعي: بعض طبقات NF تتجنّب المشتقّات المعدومة بترجمة (shfit).

مثال (15-5.14).

جمع عبر تحويل بدل التفاف. المعطيات: $S = X + Y$، نريد f_S بمتغيّر مساعد $U = X$. المطلوب: اشتقق الكثافة عبر التحويل $(X,Y) \to (S,U)$. الحل: الخطوة 1: $s = x + y$، $u = x$؛ الجاكوبي $\left|\begin{smallmatrix} 1 & 1 \\ 1 & 0 \end{smallmatrix}\right| = -1$، مقداره 1. الخطوة 2: $f_{S,U}(s,u) = f_{X,Y}(u, s-u)$؛ تهميش U يعطي التفاف (3.14). النتيجة: التحويل يُرجع نفس الالتفاف. الربط بالذكاء الاصطناعي: تقنيات «إعادة الت parametrization» في SGD تستخدم تحويلات لفصل الضوضاء.

التعريف

dir="ltr"> <div

when $\mathcal{N}(\boldsymbol{\mu}, \Sigma)$ is $\mathbf{X} \in \mathbb{R}^d$ vector random A **normal). (Multivariate 1.6.14 Definition**

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\tfrac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})\right). \tag{5.14}$$

dir="ltr"> <div
properties: closure Key

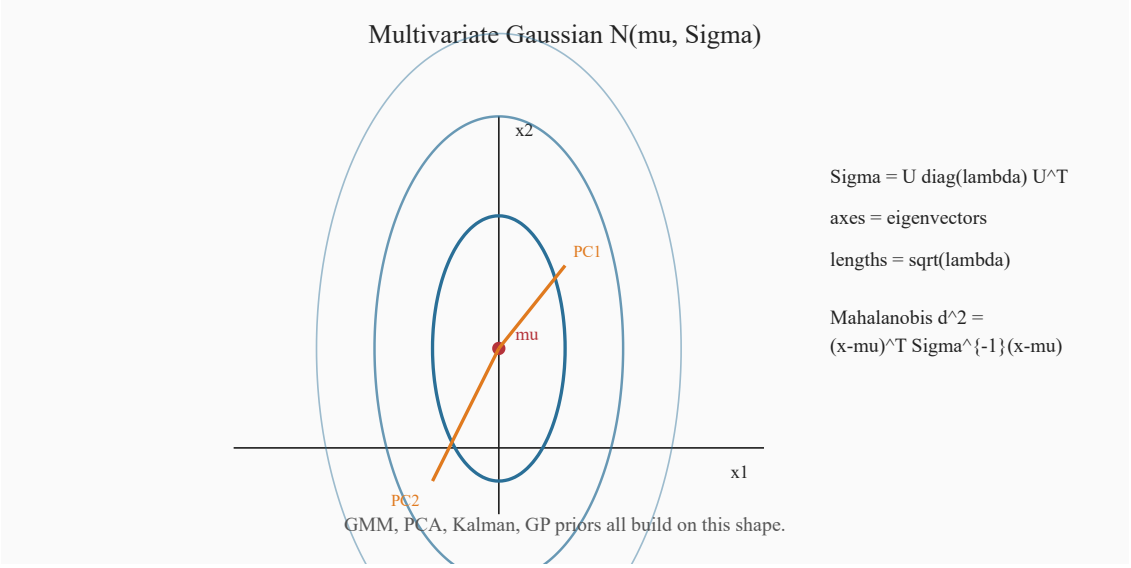
- $A\boldsymbol{\mu} + \mathbf{b}$ mean with Gaussian again is $A\mathbf{X} + \mathbf{b}$ map affine Any. $A\Sigma A^\top$ covariance ,
- Gaussian. is Gaussian a of conditional and marginal Every
- mean. the to **distance Mahalanobis** the is exponent The

جدول الرموز

الرمز	الاسم	المعنى
$\boldsymbol{\mu}$	متّجه المُتوسّط	مركز التوزيع
Σ	مصفوفة التغاير	انتشار وارتباط
$\lvert\Sigma\rvert$	محدّد التغاير	حجم الحجم
d	البُعد	عدد المتغيرات

رسم توضيحي

<figure> الشكل<figcaption> 6.14: كثافة $\mathcal{N}(\boldsymbol{\mu}, \Sigma)$ في بُعدين. المحاور هي اتجاهات eigenvectors لمصفوفة



شكل ٥.١٤: *
توزيع غاوسي متعدد المتغيرات

التغاير، وأطوالها $\sqrt{\lambda_i}$؛ المنحنيات محالات كثافة ثابتة، والمسافة ماهالانوبيس تحدّدها.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
نسيان $\lvert\Sigma\rvert^{1/2}$	يُبطل التطبيع	أدخل المحدّد
افتراض استقلال إذا كان $\mu = 0$	يحتاج Σ قطرية	افحص التغاير
خلط المُتوسّط بالوسيط	الغاوسي متماثل فقط	ينطبق هنا فقط

أمثلة محلولة على التوزيع الغاوسي متعدّد المتغيرات (15 مثالاً)

مثال (14.6-1).

تقييم الكثافة في نقطة. المعطيات: $\boldsymbol{\mu} = (0,0)^\top$، $\Sigma = I_2$، $\mathbf{x} = (1,1)^\top$. المطلوب: $f(\mathbf{x})$. الحل: الخطوة 1: $\lvert\Sigma\rvert = 1$، $(\mathbf{x}-\boldsymbol{\mu})^\top\Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu}) = 1+1 = 2$. الخطوة 2: $f = \frac{1}{2\pi}e^{-1} \approx 0.0585$. النتيجة: $0.0585 \approx$. الربط بالذكاء الاصطناعي: احتمال البيانات تحت نموذج غاوسي (log-likelihood).

مثال (14.6-2).

تحويل أفيني يبقيه غاوسيّاً. المعطيات: $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$، $\mathbf{Y} = A\mathbf{X} + \mathbf{b}$. المطلوب: متوسّط وتغاير $\mathbf{Y}$. الحل: الخطوة 1: $\mathbb{E}[\mathbf{Y}] = A\boldsymbol{\mu}+\mathbf{b}$. الخطوة 2: $\mathrm{Cov}(\mathbf{Y}) = A\Sigma A^\top$. النتيجة: $\mathcal{N}(A\boldsymbol{\mu}+\mathbf{b}, A\Sigma A^\top)$. الربط بالذكاء الاصطناعي: طبقة خطّية على تمثيل غاوسي (انظر 14.5-9).

مثال (14.6-3).

الهامشية غاوسية. المعطيات: $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2)$ غاوسي بكتلتين $\boldsymbol{\mu} = (\mu_1, \mu_2)$، $\Sigma = \begin{pmatrix}\Sigma_{11} & \Sigma_{12}\\ \Sigma_{21} & \Sigma_{22}\end{pmatrix}$. المطلوب: توزيع $\mathbf{X}_1$ وحده. الحل: الخطوة 1: الهامشية تستخرج الكتلة الموافقة: $\mathbf{X}_1 \sim \mathcal{N}(\mu_1, \Sigma_{11})$. النتيجة: غاوسي بالهامش. الربط بالذكاء الاصطناعي: اختيار ميزات فرعية من نموذج مشترك غاوسي.

مثال (14.6-4).

التوزيع الشرطي غاوسي. المعطيات: نفس البنية في (14.6-3). المطلوب: $\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2$. الحل: الخطوة 1: المُتوسّط الشرطي $\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$. الخطوة 2: التغاير الشرطي $\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$. النتيجة: $\mathcal{N}(\cdot,\cdot)$ (غاوسي). الربط بالذكاء الاصطناعي: تصفية كالمان (Kalman) تعتمد هذا الشرطي الغاوسي.

مثال (14.6-5).

مسافة ماهالانوبيس للشذوذ. المعطيات: $\boldsymbol{\mu} = (0,0)$، $\Sigma = \begin{pmatrix}4 & 0\\ 0 & 1\end{pmatrix}$، نقطة $\mathbf{x} = (4,0)$. المطلوب: المسافة D^2. الحل: الخطوة 1: $\Sigma^{-1} = \begin{pmatrix}1/4 & 0\\ 0 & 1\end{pmatrix}$. الخطوة 2: $D^2 = (4,0)\Sigma^{-1}(4,0)^\top = 16 \times \frac{1}{4} = 4$. النتيجة: $D^2 = 4$ (على حدّ 2σ في اتجاه x_1). الربط بالذكاء الاصطناعي: كشف الشذوذ في فضاء الميزات دون افتراض استقلال.

مثال (6-6.14).

التبييض (Whitening). المعطيات: $\mathbf{X} \sim \mathcal{N}(0, \Sigma)$، نريد $\mathbf{Z} = \Sigma^{-1/2}\mathbf{X}$. المطلوب: توزيع $\mathbf{Z}$. الحل: الخطوة 1: من (2-6.14) التغاير $= \Sigma^{-1/2}\Sigma\Sigma^{-1/2} = I$. النتيجة: $\mathcal{N}(0, I)$ (مبيّض). الربط بالذكاء الاصطناعي: تبييض البيانات قبل النماذج الخطّية يُسرّع التقارب.

مثال (7-6.14).

PCA عبر القيم الذاتية. المعطيات: Σ بمتجهات ذاتية u_1, u_2 وقيم $\lambda_1 > \lambda_2$. المطلوب: أي اتجاه يحتفظ بأكبر تباين؟ الحل: الخطوة 1: التباين على اتجاه u_i يساوي λ_i. الخطوة 2: u_1 (القيمة الأكبر) يحتفظ بأكثر تباين. النتيجة: الإسقاط على u_1. الربط بالذكاء الاصطناعي: PCA = اختزال بُعد عبر eigenvectors لأكبر تباين.

مثال (8-6.14).

مُسبَق غاوسي لعمليات غاوسية. المعطيات: عند نقاط $x_1, \ldots, x_n$، المتجه $\mathbf{f} \sim \mathcal{N}(0, K)$. المطلوب: ما نوع التوزيع الهامشي لأي مجموعة فرعية؟ الحل: الخطوة 1: من (3-6.14) أي هامشية غاوسية بكلّية K الموافقة. النتيجة: غاوسية (أساس GP). الربط بالذكاء الاصطناعي: العمليات الغاوسية (Gaussian Processes) priors تستخدم هذا لكل عيّنة منتهية.

مثال (9-6.14).

خطوة تنبّؤ كالمان. المعطيات: حالة $\mathbf{x}_t \sim \mathcal{N}(\hat{x}, P)$، قياس $z = Hx + v$، $v \sim \mathcal{N}(0, R)$. المطلوب: التوزيع اللاحق بعد القياس. الحل: الخطوة 1: بدمج التوزيعين الغاوسيَّيْن نحصل على لاحق غاوسي (4-6.14). الخطوة 2: كسب كالمان $K = PH^\top(HPH^\top + R)^{-1}$. النتيجة: لاحق $\mathcal{N}(\hat{x} + K(z - H\hat{x}), (I - KH)P)$. الربط بالذكاء الاصطناعي: تتبّع الحالة في الروبوتات والملاحة.

مثال (10-6.14).

LDA/QDA والقرار. المعطيات: صنفان كلاهما غاوسي بـ Σ مشترك (LDA). المطلوب: حدود القرار. الحل: الخطوة 1: تساوي اللوغاريتمات يعطي حدّاً خطّياً (لأن Σ يلغي في الفرق). الخطوة 2: بتباين مختلف (QDA) يصبح حدّاً تربيعياً. النتيجة: حدّ خطّي/تربيعي. الربط بالذكاء الاصطناعي: المصنّفات التمييزية الخطّية والتربيعية.

مثال (11-6.14).

مكوّنات مستقلّة = تغاير قطري. المعطيات: $\Sigma = \mathrm{diag}(\sigma_1^2, \sigma_2^2)$. المطلوب: هل المتغيران مستقلّان؟ الحل: الخطوة 1: الكثافة $f_1 f_2 = \prod_i \frac{1}{\sqrt{2\pi}\sigma_i} e^{-x_i^2/(2\sigma_i^2)} = f(x_1, x_2)$. النتيجة: مستقلّان. الربط بالذكاء الاصطناعي: ICA/PCA تهدف لإنتاج مكوّنات غير مرتبطة/مستقلّة.

مثال (6.14-12).

الارتباط من المصفوفة. المعطيات: $\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$. المطلوب: ارسم شكل الكثافة عند $\rho = 0.8$. الحل: الخطوة 1: المحاور المميّزة تدور بزاوية $45°$، والانكماش على المحور الثانوي $\sqrt{1-\rho}$. الخطوة 2: عند $\rho = 0.8$ الانكماش $\sqrt{0.2} \approx 0.447$. النتيجة: إهليلج مائلة بشدّة. الربط بالذكاء الاصطناعي: فهم ارتباط الميزات يوجّه هندستها.

مثال (6.14-13).

أخذ عيّنة بتحليل تشوليسكي. المعطيات: $\mathbf{X} \sim \mathcal{N}(0, \Sigma)$، لدينا $\Sigma = LL^\top$ (Cholesky). المطلوب: كيف نولّد عيّنة؟ الحل: الخطوة 1: ولّد $\mathbf{z} \sim \mathcal{N}(0, I)$ ثم $\mathbf{x} = L\mathbf{z}$. الخطوة 2: من (6.14-2) $\mathbf{x} \sim \mathcal{N}(0, LL^\top) = \mathcal{N}(0, \Sigma)$. النتيجة: عيّنة صحيحة. الربط بالذكاء الاصطناعي: تهيئة/أخذ عيّنات من توزيعات معقّدة في التدريب.

مثال (6.14-14).

إهليلج الكثافة الثابتة. المعطيات: نريد محيط $c = (\mathbf{x}-\mu)^\top \Sigma^{-1}(\mathbf{x}-\mu) = D^2$. المطلوب: ما شكله لمتى $c = 1, 4, 9$؟ الحل: الخطوة 1: المحيط إهليلج بمحاور $\sqrt{c\lambda_i}$ على اتجاهات eigenvectors. الخطوة 2: c أكبر $\rightarrow$ إهليلج أوسع (1σ، 2σ، 3σ). النتيجة: ثلاثة محيطات متّسعة. الربط بالذكاء الاصطناعي: رسم مناطق الثقة (confidence ellipses) في تحليل البيانات.

مثال (6.14-15).

تباعد KL بين غاوسيَّيْن. المعطيات: $P = \mathcal{N}(\mu_0, \Sigma_0)$، $Q = \mathcal{N}(\mu_1, \Sigma_1)$. المطلوب: صيغة $\mathrm{KL}(P\|Q)$ المغلقة. الحل: الخطوة 1: $\mathrm{KL} = \frac{1}{2}[\ln \frac{|\Sigma_1|}{|\Sigma_0|} - d + \mathrm{tr}(\Sigma_1^{-1}\Sigma_0) + (\mu_1-\mu_0)^\top \Sigma_1^{-1}(\mu_1-\mu_0)]$. النتيجة: مغلقة الصيغة. الربط بالذكاء الاصطناعي: KL يظهر في VAE/ELBO وقياس التشابه بين التوزيعات.

التعريف

dir="ltr"> <div

Definition 6.14.1 (MGF and characteristic function). The **moment generating function** of a random variable X is $M_X(t) = \mathbb{E}[e^{tX}]$ (where defined). The **characteristic function** is $\phi_X(t) = \mathbb{E}[e^{itX}]$, defined for all $t \in \mathbb{R}$. They characterize distribution uniquely, and for independent sums the MGF/CF of the sum is the **product** of the individual ones.

$$M_X(t) = \mathbb{E}[e^{tX}]; \qquad M_{X+Y}(t) = M_X(t) M_Y(t) \ \ (X \perp Y). \tag{6.14}$$

dir="ltr"> <div

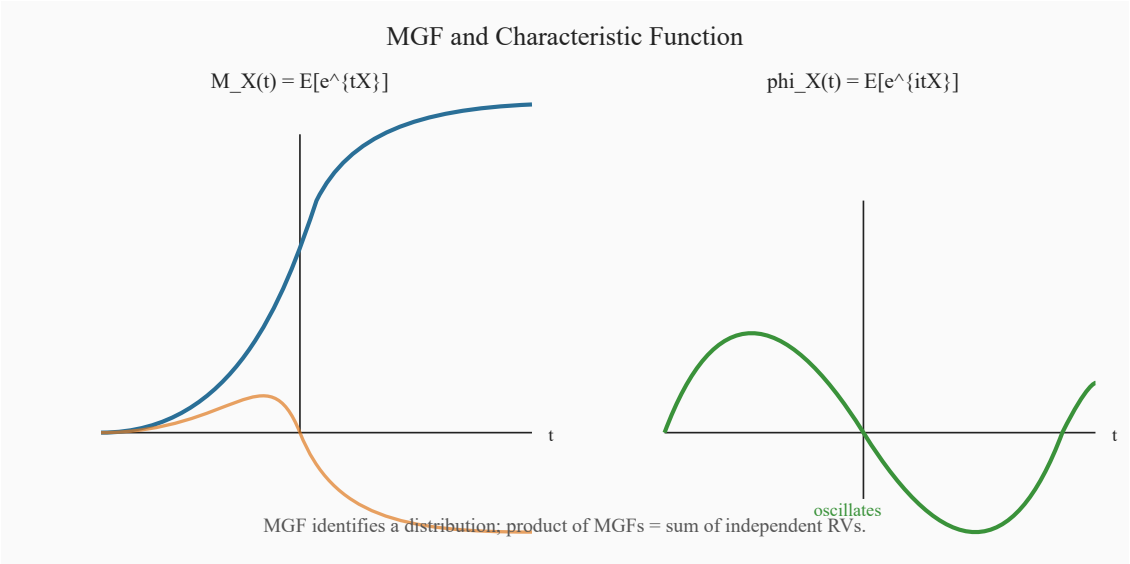
The product rule (6.14) is the algebraic engine behind sums of independent RVs: convolutions become multiplications in the MGF space. The characteristic function exists always and powers the Central Limit Theorem.

جدول الرموز

الرمز	الاسم	المعنى
$M_X(t)$	MGF	مولّد اللحظات
$\phi_X(t)$	الدالّة المميّزة	$\mathbb{E}[e^{itX}]$
t	المتغيّر المزدوج	معامل التحويل
i	الوحدة التخيّلية	$i^2 = -1$

رسم توضيحي

<figure> الشكل<figcaption> 7.14: MGF $M_X(t)$ (يسار) يحدّد التوزيع ويتضاعف عند جمع المستقلّات؛ والدالّة



شكل ٦.١٤: *
الدوال المولّدة للحظات والمميّزة

المميّزة $\phi_X(t)$ (يمين) تتذبذب دوماً وتوجد لكل t، وهي أساس مبرهنة الحدّ المركزي.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اعتبار MGF موجودة دائماً	قد لا توجد	استخدم ϕ_X
خلط MGF باللحظة	$M^{(k)}(0) = \mathbb{E}[X^k]$	اشتقق عند 0
نسيان الاستقلال للضرب	لا ينطبق مع الارتباط	اشترط $X \perp Y$

أمثلة محلولة على الدوال المولّدة للحظات (15 مثالاً)

مثال (14.7-1).

MGF للبرنولي. المعطيات: $X \sim \text{Bern}(p)$. المطلوب: $M_X(t)$. الحل: الخطوة 1: $M_X(t) = \mathbb{E}[e^{tX}] = pe^t + (1-p)$. النتيجة: $1 - p + pe^t$. الربط بالذكاء الاصطناعي: لبنة بناء MGF ذي الحدّين.

مثال (14.7-2).

MGF لذي الحدّين من الجداء. المعطيات: $X = \sum_{i=1}^{n} X_i$، X_i برنولي (p) مستقلّة. المطلوب: $M_X(t)$. الحل: الخطوة 1: بـ (14.6) $M_X(t) = [M_{X_1}(t)]^n = (1 - p + pe^t)^n$. النتيجة: $(1 - p + pe^t)^n$. الربط بالذكاء الاصطناعي: يطابق لحظات دقّة دفعة من n عيّنة.

مثال (14.7-3).

MGF لبواسون. المعطيات: $X \sim \text{Pois}(\lambda)$. المطلوب: $M_X(t)$. الحل: الخطوة 1: $M_X(t) = e^{-\lambda} \sum (\lambda e^t)^k / k! = e^{-\lambda} e^{\lambda e^t}$. الخطوة 2: $\sum e^{tk} e^{-\lambda} \lambda^k / k! = e^{\lambda(e^t - 1)}$. النتيجة: $e^{\lambda(e^t-1)}$. الربط بالذكاء الاصطناعي: لحظات معدّل الأحداث (mean/variance).

مثال (14.7-4).

MGF للأسّي. المعطيات: $X \sim \text{Exp}(\lambda)$. المطلوب: $M_X(t)$ (لـ $t < \lambda$). الحل: الخطوة 1: $\lambda \int_0^\infty e^{-(\lambda - t)x} dx = \frac{\lambda}{\lambda - t}$. النتيجة: $\frac{\lambda}{\lambda - t}$، $t < \lambda$. الربط بالذكاء الاصطناعي: زمن الخدمة وتحليل الطوابير.

مثال (14.7-5).

MGF للغاوسي. المعطيات: $X \sim \mathcal{N}(\mu, \sigma^2)$. المطلوب: $M_X(t)$. الحل: الخطوة 1: أكمل المربّع: $\mathbb{E}[e^{tX}] = e^{\mu t + \sigma^2 t^2 / 2}$. النتيجة: $e^{\mu t + \frac{1}{2}\sigma^2 t^2}$. الربط بالذكاء الاصطناعي: لحظات خطأ التنبؤ والتوزيعات المشتقّة.

مثال (14.7-6).

MGF لغاما. المعطيات: $X \sim \text{Gamma}(\alpha, \beta)$. المطلوب: $M_X(t)$ (لـ $t < \beta$). الحل: الخطوة 1: $(\frac{\beta}{\beta - t})^\alpha \int_0^\infty e^{tx} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} dx$. النتيجة: $(1 - t/\beta)^{-\alpha}$. الربط بالذكاء الاصطناعي: مجموع أسّيات = غاما (انظر 14.4-7).

مثال (14.7-7).

جمع ذي الحدّين عبر MGF. المعطيات: $X \sim \text{Bin}(n_1, p)$، $Y \sim \text{Bin}(n_2, p)$ مستقلّان. المطلوب: MGF و distribution لـ $X + Y$. الحل: الخطوة 1: $M_{X+Y} = (1 - p + pe^t)^{n_1 + n_2}$ (جداء). الخطوة 2: يطابق $\text{Bin}(n_1 + n_2, p)$. النتيجة: $\text{Bin}(n_1 + n_2, p)$. الربط بالذكاء الاصطناعي: دمج دفعتين من التصنيفات.

مثال (14.7-8).

جمع بواسون عبر MGF. المعطيات: $X \sim \text{Pois}(\lambda_1)$، $Y \sim \text{Pois}(\lambda_2)$. المطلوب: MGF لـ $X + Y$. الحل: الخطوة 1: $M = e^{\lambda_1(e^t-1)} e^{\lambda_2(e^t-1)} = e^{(\lambda_1+\lambda_2)(e^t-1)}$. النتيجة: $\text{Pois}(\lambda_1 + \lambda_2)$ (يطابق 14.4-5). الربط بالذكاء الاصطناعي: تجميع عدّادات من خدمات متعدّدة.

مثال (14.7-9).

نظرية التفرّد. المعطيات: توزيعان P, Q لهما نفس MGF على فترة. المطلوب: استنتاج. الحل: الخطوة 1: النظرية: MGF متطابق على فترة حول 0 $\Rightarrow$ التوزيعان متطابقان. النتيجة: $P = Q$. الربط بالذكاء الاصطناعي: التحقّق من تطابق توزيع المخرجات (اختبار two-sample).

مثال (14.7-10).

الدالّة المميّزة للغاوسي. المعطيات: $X \sim \mathcal{N}(0,1)$. المطلوب: $\phi_X(t)$. الحل: الخطوة 1: $\phi_X(t) = \mathbb{E}[e^{itX}] = e^{-t^2/2}$ (بتعويض $t \to it$ في MGF). النتيجة: $e^{-t^2/2}$. الربط بالذكاء الاصطناعي: أساس إثبات تقارب نحو الغاوسي (CLT).

مثال (14.7-11).

الدالّة المميّزة للمنتظم. المعطيات: $X \sim \text{Unfi}(-a, a)$. المطلوب: $\phi_X(t)$. الحل: الخطوة 1: $\frac{1}{2a}\int_{-a}^{a} e^{itx}dx = \frac{\sin(at)}{at}$. النتيجة: $\text{sinc}(at)$. الربط بالذكاء الاصطناعي: تحليل الإشارات (تحويل فوريه لإشارة مستطيلة).

مثال (14.7-12).

MGF لمربّع كاي. المعطيات: $X \sim \chi^2_k$. المطلوب: $M_X(t)$. الحل: الخطوة 1: χ^2_k = غاما$(k/2, 1/2)$، فمن (14.7-6) $M = (1-2t)^{-k/2}$. النتيجة: $(1-2t)^{-k/2}$. الربط بالذكاء الاصطناعي: إحصاءات الاختبارات (انظر 14.3-11).

مثال (14.7-13).

دالّة مولّد التراكم (CGF). المعطيات: $K_X(t) = \ln M_X(t)$ للغاوسي. المطلوب: اشتقق اللحظتين الأولى والثانية من CGF. الحل: الخطوة 1: $K(t) = \mu t + \frac{1}{2}\sigma^2 t^2$، $K'(0) = \mu$، $K''(0) = \sigma^2$. النتيجة: اللحظة الأولى μ والثانية σ^2. الربط بالذكاء الاصطناعي: طريقة اللحظات المُتراكمة في الإحصاء.

مثال (14.7-14).

MGF للهندسي. المعطيات: $X \sim \text{Geom}(p)$ على $\{1, 2, \dots\}$. المطلوب: $M_X(t)$ (لـ $e^t(1-p) < 1$). الحل: الخطوة 1: $pe^t \sum[(1-p)e^t]^{k-1} = \frac{pe^t}{1-(1-p)e^t}$، $\sum_{k=1}^{\infty} e^{tk}p(1-p)^{k-1}$. النتيجة: $\frac{pe^t}{1-(1-p)e^t}$. الربط بالذكاء الاصطناعي: لحظات زمن الوصول (انظر 14.2-6).

مثال (14.7-15).

CLT عبر الدالّة المميّزة. المعطيات: X_i i.i.d. بـ μ, σ^2، $S_n = \frac{1}{\sqrt{n}}\sum(X_i - \mu)$. المطلوب: حدّ $\phi_{S_n}(t)$. الحل: الخطوة 1: $\phi_{S_n}(t) = [\phi_X(t/\sqrt{n})]^n \approx [1 - \frac{\sigma^2 t^2}{2n}]^n \to e^{-\sigma^2 t^2/2}$. الخطوة 2: هذا ϕ لـ $\mathcal{N}(0, \sigma^2)$. النتيجة: $S_n \xrightarrow{d} \mathcal{N}(0, \sigma^2)$. الربط بالذكاء الاصطناعي: تبرير تقارب متوسّطات الدُفعات والخطأ التجريبي نحو الغاوسي.

خيط الفصل

ربطنا في الفصل 13 الاحتمال بنظرية القياس (الفصل 10): $\mathbb{P}$ قياس بمجموع 1، والمتغيّر العشوائي دالّة قياسية. هنا أكملنا الصورة: **التوزيع** هو «دفع» (pushforward) لـ $\mathbb{P}$ عبر X إلى $\mathbb{R}^d$ — أي أنّ $P_X(B) = \mathbb{P}(X^{-1}(B))$ (المعادلة 2.13). كتلة/كثافة الاحتمال هي ببساطة وصف هذا الدفع إمّا جُملياً (PMF للمنفصل) أو كثيفاً (PDF للمستمر).

جسور الكتاب

المفهوم	من الفصل	كيف يُستخدم هنا
$\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B))$	13 (2.13)	تعريف التوزيع كدفع
التكامل كقياس ليبيسغ–ستيلتjes	10 (7.10)	$\mathbb{E}[X] = \int x\, dF_X$
التفاف/تحويل الجاكوبي	9 (التفاضل المصفوفي)	قاعدة (4.14)
القيم الذاتية والتحليل $LL^\top$	4 (التحليل/SVD)	تبييض PCA (6.14)

هذه الجسور تُبقي الكتاب متّصلاً: كل أداة توزيعية ترتكز على بُنية رياضية سبق شرحها.

١. أثبت أنّ مجموع n برنولي مستقلّة ذو حدّين (باستخدام MGF).

٢. اشتقق $\mathbb{E}[X] = 1/\lambda$ و$\mathrm{Var}(X) = 1/\lambda^2$ للأسّي.

٣. لـ $X \sim \mathcal{N}(0,1)$، أوجد $\mathbb{P}(-1 < X < 1)$ بالتقريب.

٤. إذا $Y = e^X$ و $X \sim \mathcal{N}(0,1)$، أوجد $\mathbb{E}[Y]$.

٥. تحقّق أنّ $\int_{-\infty}^{\infty} \mathcal{N}(x;\mu,\sigma^2)dx = 1$ بالتحويل $z = (x-\mu)/\sigma$.

٦. لخليط غاوسي بمكوّنين أوزان $\pi_1 = 0.7, \pi_2 = 0.3$، اكتب الكثافة الكلية.

٧. أثبت أنّ الهامشية $f_X(x) = \int f_{X,Y}$ تحفظ التطبيع.

٨. إذا X, Y غاوسيان مستقلّان، أوجد توزيع $X - Y$.

٩. باستخدام الجاكوبي، أوجد كثافة $Y = \sqrt{X}$ لـ X غاما.

١٠. أثبت أنّ $\phi_{aX+b}(t) = e^{itb}\phi_X(at)$ للدالّة المميّزة.

١١. لـ $X \sim \mathrm{Pois}(\lambda)$، استخدم MGF لإيجاد $\mathbb{E}[X]$ و$\mathbb{E}[X^2]$.

١٢. في MVN ثنائي بـ $\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$، أوجد اتجاهات eigenvectors.

١٣. حوّل $U(0,1)$ إلى $\mathrm{Exp}(1)$ عبر التوزيع التراكمي العكسي.

١٤. أثبت أنّ مجموع مستقلّين χ^2 يبقى χ^2 (عبر MGF).

١٥. عيّة مسافة ماهالانوبيس لنقطة عند $\boldsymbol{\mu}$ تساوي 0.

١٦. إذا $X \perp Y$، أثبت $\mathrm{Cov}(X,Y) = 0$ (العكس غير صحيح عموماً).

١٧. اشتقق إنتروبيا برنولي $H(p)$ وأوجد p الذي يُعظّمها.

١٨. لـ $X \sim \text{Beta}(1,1)$، أثبت أنها $\text{Unfi}(0,1)$.

١٩. استخدم CLT لتقريب $\mathbb{P}(\text{Bin}(100, 0.5) > 60)$.

٢٠. صمّم شرطاً مسبقاً (prior) غاوسياً لوزن في شبكة عصبية وعبّر عن لوغاريتم الاحتمال المسبق.

غطّى هذا الفصل «قاموس» التوزيعات القياسية وربطه بالبُنى السابقة:

- **المنفصلة** (برنولي/ذو الحدّين/بواسون/هندسي/فئوي) تصف الأعداد والفئات — أساس التصنيف والكشف.
- **المستمرة** (منتظم/أسّي/غاوسي/لابلاس/غاما/بيتا/كاي^2) تصف الكمّيات والضوضاء — أساس الخسائر والشروط المسبقة.
- **المشتركة والتهميش والالتفاف** (3.14) تتيح الاستدلال وجمع الضوضاء.
- **تحويل المتغيرات** (4.14) يحفظ الكتلة عبر محدّد الجاكوبي — أساس التدفقات العادية.
- **الغاوسي متعدّد المتغيرات** (5.14) يغلق تحت الأفيني والهامش/الشرط — أساس GMM والعمليات الغاوسية وكالمان.
- **الدالّة/MGF المميّزة** (6.14) تُحدّد التوزيع وتُضاعف عند الجمع — أساس CLT.

كل هذه التوزيعات هي «دفع» لـ $\mathbb{P}$ عبر المتغيّر العشوائي (2.13)، وتُحسب لحظاتها عبر التكامل $\int x\, dF_X$ (7.10). الكتاب يمضي نحو اللحظات نفسها (المُتوسّط، التباين، التغاير) في الفصل 15.

الرمز	المعنى
$p_X(k), f_X(x)$	كتلة/كثافة الاحتمال
$F_X(x)$	الدالة التراكمية
$\mathcal{N}(\mu, \sigma^2)$	التوزيع الغاوسي
$\text{Exp}(\lambda), \text{Pois}(\lambda)$	أسّي/بواسون
$\text{Bin}(n,p), \text{Bern}(p)$	ذو الحدّين/برنولي
Σ	مصفوفة التغاير
J	الجاكوبي
$M_X(t), \phi_X(t)$	الدالّة/MGF المميّزة
D^2	مسافة ماهالانوبيس

١. N. A. Kolmogorov, *Foundations of the Theory of Probability*, Chelsea, 1950.

٢. M. C. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006. (Ch. 2).

٣. K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012. (Ch. 2–3).

٤. R. L. Berger, G. Casella, *Statistical Inference*, 2nd ed., Duxbury, 2002.

٥. D. J. C. MacKay, *Information Theory, Inference and Learning Algorithms*, Cambridge, 2003.

٦. I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016. (Ch. 3).

٧. A. Papoulis, S. U. Pillai, *Probability, Random Variables and Stochastic Processes*, McGraw-Hill, 2002.

٨. C. P. Robert, G. Casella, *Monte Carlo Statistical Methods*, Springer, 2004.

المتوقّع، التباين، والمصفوفات الموجبة

في الفصلين 13 و14 بنينا فضاء الاحتمال ثم «قاموس» التوزيعات. لكن التعلّم الآلي لا يتعامل مع التوزيع كاملاً في أغلب الأحيان — إنه يحتاج **أرقاماً مختصرة** تلخّصه: المُتوسّط (المتوقّع) يخبرنا بـ«أين يقع»، والتباين يخبرنا بـ«كم ينتشر»، ومصفوفة التغاير والمصفوفات الموجبة نصف التحديد (PSD) تحكم شكل الارتباط وهندسة التحسين.

هذا الفصل هو «جسر العدد» بين الاحتمال والجبر الخطّي: نعيد استخدام القيم الذاتية (الفصل 4)، والتفاضل المصفوفي (الفصل 9)، والتكامل كقياس (الفصل 10)، لنبني الأدوات التي يقوم عليها كل من:

- تقدير المُعاملات (المُتوسّط، التباين، تقدير المتراجحات)؛
- تحليل الخطأ وعدم اليقين (متراجحات ماركوف/تشيبيشِف)؛
- التحسين المحدّب (الهيسيّة الموجبة، شرطة مترافقة)؛
- المعلوماتية الإحصائية (معلومات فيشر، كرامير–راو، PCA، LDA).

خريطة الفصل

القسم	المحتوى	النظرية/القانون
2.15	المتوقّع وقانون الإحصائي النائم (LOTUS)	(1.15) التوقّع المتكامل
3.15	التباين والتباين المشترك	(2.15) تفكيك التباين
4.15	متراجحات جنسن وماركوف وتشيبيشِف	(3.15) تشيبيشِف
5.15	المصفوفات الموجبة نصف/التحديد	(4.15) التعريف التربيعي
6.15	المكمّل الشورّي والتغاير	(5.15) شرط شور
7.15	التطبيقات: فيشر، PCA، كرامير–راو	(6.15) حدّ كرامير–راو

التعريف

dir="ltr"> <div

Definition 1.2.15 (Expectation). For X RV an with F_X distribution,

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \, dF_X(x) = \begin{cases} \sum_{k} x_k \, p_X(x_k), & \text{discrete,} \\ \int x \, f_X(x) \, dx, & \text{continuous.} \end{cases}$$

The **Law of the Unconscious Statistician (LOTUS)** lets us take expectation through any function g:

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \, dF_X(x).$$

/div>

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \, dF_X(x). \tag{1.15}$$

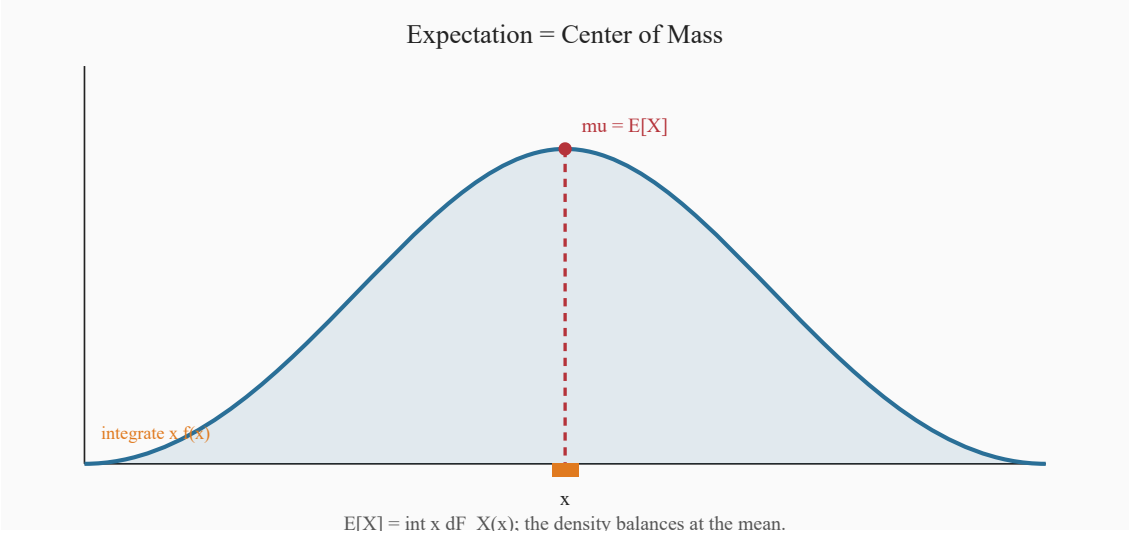
dir="ltr"> <div
loss", "expected converts it ML: in identity most-used single the is (1.15) Equation
data the over integral an into directly norm" gradient "expected or accuracy", "expected
.$g(X)$ of distribution the derive to need no — distribution

جدول الرموز

الرمز	الاسم	المعنى
$\mathbb{E}[X]$	المتوقّع	المُتوسّط المرجّح بالقياس
dF_X	عنصر القياس	كثافة أو كتلة
g	دالّة محوّلة	ما نريد متوسّطه
LOTUS	قانون الإحصائي النائم	$\mathbb{E}[g(X)]$ بلا توزيع g

رسم توضيحي

<figure> الشكل<figcaption> 1.15: المتوقّع $\mathbb{E}[X]$ هو نقطة توازن الكثافة — تكامل x مُرجّحاً بـ $f_X(x)$. كل لحظة



شكل ١.١٥: *
المتوقّع كمركز كتلة

مركزية تُحسب حول هذه النقطة.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
$\mathbb{E}[g(X)] = g(\mathbb{E}[X])$	صحيح فقط خطّياً	استخدم LOTUS
نسيان وزن الكثافة	يقع الخطأ المنتظم	اضرب بـ f_X
خلط المتوقّع بالوسيط	يختلفان عموماً	فرّقهما

أمثلة محلولة على المتوقّع و LOTUS (15 مثالاً)

مثال (15.2-1).

متوقّع برنولي. المعطيات: $X \sim \text{Bern}(p)$. المطلوب: $\mathbb{E}[X]$. الحل: الخطوة 1: $\mathbb{E}[X] = 0 \cdot (1-p) + 1 \cdot p$. النتيجة: p. الربط بالذكاء الاصطناعي: دقّة المصنّف = متوقّع الإصابة الصحيحة.

مثال (15.2-2).

متوقّع ذي الحدّين عبر LOTUS. المعطيات: $X \sim \text{Bin}(n,p)$. المطلوب: $\mathbb{E}[X]$. الحل: الخطوة 1: $X = \sum_{i=1}^{n} X_i$، X_i برنولي؛ بالخطّية $\mathbb{E}[X] = \sum \mathbb{E}[X_i] = np$. النتيجة: np. الربط بالذكاء الاصطناعي: عدد التصنيفات الصحيحة في دفعة = الدقّة $\times\, n$.

مثال (15.2-3).

متوقّع بواسون. المعطيات: $X \sim \text{Pois}(\lambda)$. المطلوب: $\mathbb{E}[X]$. الحل: الخطوة 1: LOTUS بـ $\sum_{k\geq 0} k e^{-\lambda}\lambda^k/k!$. $= \lambda \sum_{k\geq 1} e^{-\lambda}\lambda^{k-1}/(k-1)! = \lambda$. النتيجة: λ. الربط بالذكاء الاصطناعي: معدّل الأحداث المُتوقّع في نافذة زمنية.

مثال (15.2-4).

متوقّع منتظم مستمر. المعطيات: $X \sim \text{Unfi}(a,b)$. المطلوب: $\mathbb{E}[X]$. الحل: الخطوة 1: $\int_a^b x \,\frac{1}{b-a} dx = \frac{a+b}{2}$. النتيجة: $(a+b)/2$. الربط بالذكاء الاصطناعي: متوسّط زمن وصول موحّد في محاكاة الطوابير.

مثال (15.2-5).

متوقّع أسّي. المعطيات: $X \sim \text{Exp}(\lambda)$. المطلوب: $\mathbb{E}[X]$. الحل: الخطوة 1: $\int_0^\infty x\lambda e^{-\lambda x} dx = 1/\lambda$ (تكامل بالأجزاء). النتيجة: $1/\lambda$. الربط بالذكاء الاصطناعي: زمن الاستجابة المتوقّع لخدمة.

مثال (15.2-6).

متوقّع غاوسي. المعطيات: $X \sim \mathcal{N}(\mu,\sigma^2)$. المطلوب: $\mathbb{E}[X]$. الحل: الخطوة 1: بالتعويض $z = (x-\mu)/\sigma$، التكامل حول الصفر يلغي، فيبقى μ. النتيجة: μ. الربط بالذكاء الاصطناعي: مركز توزيع الخطأ قبل التنشيط.

مثال (15.2-7).

متوقّع غاوسي. المعطيات: $X \sim \mathcal{N}(\mu,\sigma^2)$. المطلوب: $\mathbb{E}[X^2]$ لـ LOTUS. الحل: الخطوة 1: $\mathbb{E}[X^2] = \int x^2 f_X(x)dx = \mu^2 + \sigma^2$ (بإكمال المربّع). النتيجة: $\mu^2 + \sigma^2$. الربط بالذكاء الاصطناعي: اللحظة الثانية تدخل

في الطاقة $\mathbb{E}[\|x\|^2]$.

مثال (15.2-8).

LOTUS يعطي MGF. المعطيات: $M_X(t) = \mathbb{E}[e^{tX}]$. المطلوب: اربطه بـ (15.1). الحل: الخطوة 1: مع $g(X) = e^{tX}$، LOTUS يعطي $M_X(t) = \int e^{tx} dF_X(x)$ — نفس (6.14). النتيجة: MGF هو متوقّع دالّة أسّية. الربط بالذكاء الاصطناعي: لحظات الخسالة المُولّدة (انظر 7.14).

مثال (15.2-9).

دالّة المؤشّر تعطي احتمالاً. المعطيات: $g(x) = \mathbf{1}_{\{x>a\}}$. المطلوب: $\mathbb{E}[g(X)]$. الحل: الخطوة 1: $\mathbb{E}[\mathbf{1}_{X>a}] = \mathbb{P}(X > a)$. (LOTUS) النتيجة: الاحتمال = متوقّع المؤشّر. الربط بالذكاء الاصطناعي: قياس معدّل «التجاوز» في مراقبة النموذج.

مثال (15.2-10).

الخطر المتوقّع (Expected Risk). المعطيات: خسارة $\ell(\hat{y}, y)$، توزيع بيانات P. المطلوب: عبّر عن الخطر المتوقّع. الحل: الخطوة 1: $R(f) = \mathbb{E}_{(x,y)\sim P}[\ell(f(x), y)] = \int \ell(f(x), y)\, dP(x, y)$. (LOTUS) النتيجة: تكامل الخسارة على التوزيع. الربط بالذكاء الاصطناعي: الهدف الحقيقي للتعلّم = تقليل الخطر المتوقّع.

مثال (15.2-11).

إنتروبيا كمتوقّع سالب اللوغاريتم. المعطيات: X بكتلة $p(x)$. المطلوب: $H(X) = \mathbb{E}[-\log p(X)]$. الحل: الخطوة 1: $\sum_x -p(x)\log p(x)$ (LOTUS مع $g = -\log p$). النتيجة: إنتروبيا = متوقّع اللوغاريتم السالب. الربط بالذكاء الاصطناعي: خسارة الإنتروبيا المتقاطعة هي متوقّع $-\log p_\theta(y)$.

مثال (15.2-12).

متوسّط ReLU لدخل غاوسي. المعطيات: $Z \sim \mathcal{N}(0, 1)$، $Y = \max(0, Z)$. المطلوب: $\mathbb{E}[Y]$. الحل: الخطوة 1: $\mathbb{E}[\max(0, Z)] = \int_0^\infty z\phi(z)dz = \phi(0) = 1/\sqrt{2\pi} \approx 0.399$. النتيجة: ≈ 0.399. الربط بالذكاء الاصطناعي: متوسّط خرج ReLU للضوضاء المعيارية (تحليل الشبكات).

مثال (15.2-13).

تفكيك الخطأ التربيعي. المعطيات: مُقدّر $\hat{\theta}$ لمعامل θ. المطلوب: عبّر عن $\mathbb{E}[(\hat{\theta} - \theta)^2]$ عبر LOTUS. الحل: الخطوة 1: $\mathbb{E}[(\hat{\theta} - \theta)^2] = \mathrm{Var}(\hat{\theta}) + (\mathbb{E}[\hat{\theta}] - \theta)^2$ (تُثبت بإكمال المربّع). النتيجة: تباين + انحياز^2 (تمهيد لتفكيك الانحياز/التباين). الربط بالذكاء الاصطناعي: مسامحة الانحياز مقابل التباين في النماذج.

مثال (2.15-14).

متوقّع جداء من توزيع مشترك. المعطيات: $f_{X,Y}$ كما في (4.14-1). المطلوب: $\mathbb{E}[XY]$. الحل: الخطوة 1: $\sum_{x,y} xy\, f_{X,Y}(x,y) = 0\cdot 0\cdot 0.4 + 0\cdot 1\cdot 0.1 + 1\cdot 0\cdot 0.2 + 1\cdot 1\cdot 0.3 = 0.3$. النتيجة: 0.3. الربط بالذكاء الاصطناعي: لحظة مشتركة تدخل في التغاير (3.15).

مثال (2.15-15).

تحويل ميزة ثم متوقّعها. المعطيات: $Y = \log(1+e^{Z})$ (سوفتماكس لوغيت)، $Z \sim \mathcal{N}(0,1)$. المطلوب: قدّر $\mathbb{E}[Y]$ بالتقريب. الحل: الخطوة 1: للقيم الصغيرة $Y \approx \max(0,Z) + \log 2$؛ تقريباً $\mathbb{E}[Y] \approx 0.399 + 0.693 \approx 1.09$. الخطوة 2: القيمة الدقيقة تتطلب تكاملاً عددياً لكن الترتيب صحيح. النتيجة: ≈ 1.09. الربط بالذكاء الاصطناعي: متوقّع احتمال السوفتماكس كدالّة لوغيت.

التعريف

dir="ltr"> <div
For .$\mathrm{Var}(X) = \mathbb{E}[(X-\mu)^2] = \mathbb{E}[X^2] - \mu^2$ **covariance). and (Variance 1.3.15 Definition**
The .$\Sigma_{ij} = \mathrm{Cov}(X_i, X_j) = \mathbb{E}[(X_i-\mu_i)(X_j-\mu_j)]$ is **matrix covariance** the vector, random a
.$\rho_{ij} = \Sigma_{ij} / \sqrt{\Sigma_{ii}\Sigma_{jj}}$ is correlation

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2; \qquad \Sigma_{ij} = \mathbb{E}[(X_i-\mu_i)(X_j-\mu_j)]. \tag{2.15}$$

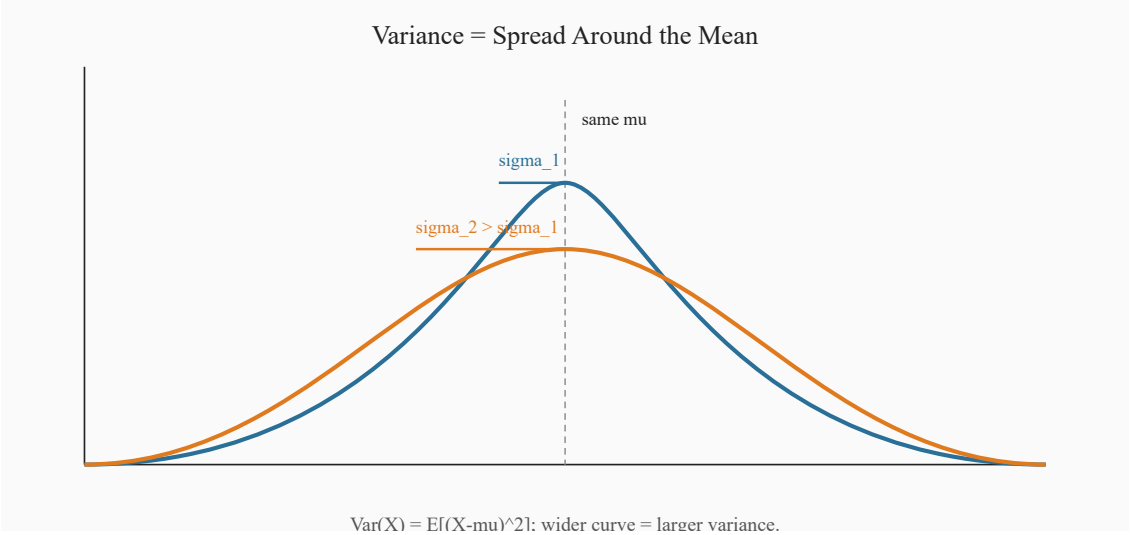
dir="ltr"> <div
spread, prediction quantfiies variance uncertainty: for workhorse the is (2.15) Equation
high in spread that of shape the is $(5.15$§ see PSD, $(\text{always } \Sigma$ matrix covariance the and
dimensions.

جدول الرموز

الرمز	الاسم	المعنى
$\mathrm{Var}(X)$	التباين	انتشار حول المتوسّط
Σ	مصفوفة التغاير	ارتباط زوجي
ρ	معامل الارتباط	$[-1,1]$
μ	المتوسّط	$\mathbb{E}[X]$

رسم توضيحي

<figure> الشكل<figcaption> 2.15: منحنيان بنفس المتوسّط μ وتباينين مختلفين. التباين الأكبر (برتقالي) يعني عدم يقين أكبر في التنبؤ — جوهر تحليل الخطأ.</figcaption> </figure>



شكل ١٥.٢: *
التباين كانتشار

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
$\mathrm{Var}(X+Y)=\mathrm{Var}(X)+\mathrm{Var}(Y)$ دائماً	يحتاج استقلالاً	أضف $2\mathrm{Cov}$
التباين سالب	مستحيل	هو متوقّع مربّع
ارتباط صفر = استقلال	فقط للغاوسي	عموماً لا

أمثلة محلولة على التباين والتباين المشترك (15 مثالاً)

مثال (15.1-3).

تباين برنولي. المعطيات: $X \sim \mathrm{Bern}(p)$. المطلوب: $\mathrm{Var}(X)$. الحل: الخطوة 1: $\mathbb{E}[X^2] = p$، فـ $\mathrm{Var} = p - p^2 = p(1-p)$. النتيجة: $p(1-p)$. الربط بالذكاء الاصطناعي: تباين دقّة التصنيف حول قيمتها.

مثال (15.2-3).

تباين ذي الحدّين. المعطيات: $X \sim \mathrm{Bin}(n,p)$. المطلوب: $\mathrm{Var}(X)$. الحل: الخطوة 1: مجموع n برنولي مستقلّة $\Rightarrow$ التباينات تُجمع: $np(1-p)$. النتيجة: $np(1-p)$. الربط بالذكاء الاصطناعي: تباين عدد الإصابات في دفعة.

مثال (15.3-3).

تباين بواسون. المعطيات: $X \sim \mathrm{Pois}(\lambda)$. المطلوب: $\mathrm{Var}(X)$. الحل: الخطوة 1: من (14-2.14) $\mathrm{Var} = \lambda$. النتيجة: λ. الربط بالذكاء الاصطناعي: تشتّت زائد (overdispersion) إن تجاوز λ.

مثال (3.15-4).

تباين ثابت يساوي صفراً. المعطيات: $X = c$ دوماً. المطلوب: $\mathrm{Var}(X)$. الحل: الخطوة 1: $\mathbb{E}[(c-c)^2] = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: المعامل المُحمّد لا تباين له.

مثال (3.15-5).

تحجيم التباين. المعطيات: $Y = aX + b$. المطلوب: $\mathrm{Var}(Y)$. الحل: الخطوة 1: $\mathrm{Var}(aX+b) = a^2\mathrm{Var}(X)$ (الإزاحة لا تؤثّر). النتيجة: $a^2\mathrm{Var}(X)$. الربط بالذكاء الاصطناعي: توحيد (standardization) يقيس التباين إلى 1.

مثال (3.15-6).

تباين مجموع مستقلّ. المعطيات: X, Y مستقلّان. المطلوب: $\mathrm{Var}(X+Y)$. الحل: الخطوة 1: $\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$ (يختفي التغاير). النتيجة: مجموع التباينات. الربط بالذكاء الاصطناعي: ضوضاء مستشعرات مستقلّة تُجمع تبايناً.

مثال (3.15-7).

تباين مجموع مترابط. المعطيات: $\mathrm{Var}(X) = \sigma_1^2$، $\mathrm{Var}(Y) = \sigma_2^2$، $\mathrm{Cov}(X,Y) = c$. المطلوب: $\mathrm{Var}(X+Y)$. الحل: الخطوة 1: $\sigma_1^2 + \sigma_2^2 + 2c$. النتيجة: يزيد بالارتباط الموجب. الربط بالذكاء الاصطناعي: ميزات مترابطة تُضخّم تباين الجمع.

مثال (3.15-8).

تباين متوسّط العيّنة. المعطيات: X_i i.i.d. بتباين σ^2، $\bar{X} = \frac{1}{n}\sum X_i$. المطلوب: $\mathrm{Var}(\bar{X})$. الحل: الخطوة 1: $\mathrm{Var}(\bar{X}) = \frac{1}{n^2} \cdot n\sigma^2 = \sigma^2/n$. النتيجة: σ^2/n (يخفض بالعيّنة). الربط بالذكاء الاصطناعي: دقّة تقدير SGD تتحسّن بـ $1/n$ — أساس حجم الدفعة.

مثال (3.15-9).

تغاير من جدول مشترك. المعطيات: الجدول في (14.4-1). المطلوب: $\mathrm{Cov}(X,Y)$. الحل: الخطوة 1: $\mathbb{E}[XY] = 0.3$، $\mathbb{E}[X] = 0.5$، $\mathbb{E}[Y] = 0.4 \Rightarrow 0.1 = 0.3 - 0.2$. النتيجة: 0.1. الربط بالذكاء الاصطناعي: بناء مصفوفة التغاير من بيانات.

مثال (3.15-10).

الارتباط محدود بـ 1 (كوشي–شفارتس). المعطيات: أي X, Y. المطلوب: أثبت $|\rho| \le 1$. الحل: الخطوة 1: $\mathrm{Cov}^2(X,Y) \le \mathrm{Var}(X)\mathrm{Var}(Y)$ (مترابحة كوشي–شفارتس للحظات). الخطوة 2: القسمة على الجذور تعطي $\rho^2 \le 1$. النتيجة: $|\rho| \le 1$. الربط بالذكاء الاصطناعي: قيس ارتباط الميزات قبل الانحدار.

مثال (3.15-11).

مصفوفة تغاير غاوسية ثنائية. المعطيات: $\Sigma = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 2 \end{pmatrix}$. المطلوب: تحقّق أنها تغاير صالح (PSD). الحل: الخطوة 1: القيم الذاتية موجبة (المحدّد $2 - 0.25 = 1.75 > 0$ والأثر $3 > 0$) $\Rightarrow$ PSD. النتيجة: صالحة. الربط بالذكاء الاصطناعي: تغاير ميزتين في نموذج GMM.

مثال (3.15-12).

تغاير تحويل خطّي. المعطيات: $\mathbf{Y} = A\mathbf{X}$. المطلوب: $\text{Cov}(\mathbf{Y})$. الحل: الخطوة 1: $\text{Cov}(A\mathbf{X}) = A\Sigma_X A^\top$. النتيجة: $A\Sigma_X A^\top$. الربط بالذكاء الاصطناعي: طبقة خطّية تُعيد تشكيل التغاير (انظر 14.6-2).

مثال (3.15-13).

غير مرتبط $\neq$ مستقلّ. المعطيات: $X \sim \mathcal{N}(0,1)$، $Y = X^2$. المطلوب: هل $\text{Cov}(X,Y) = 0$؟ وهل مستقلّان؟ الحل: الخطوة 1: $\mathbb{E}[XY] = \mathbb{E}[X^3] = 0 = \mathbb{E}[X]\mathbb{E}[Y]$ $\Rightarrow$ تغاير صفر. الخطوة 2: لكن Y تُحدّد تماماً بـ X $\Rightarrow$ غير مستقلّين. النتيجة: غير مرتبطان لا يعني مستقلّين (إلا للغاوسي). الربط بالذكاء الاصطناعي: في الشبكات العميقة انعدام الارتباط الخطّي لا يضمن الاستقلال.

مثال (3.15-14).

تباين خرج ReLU غاوسي. المعطيات: $Z \sim \mathcal{N}(0,1)$. المطلوب: $\text{Var}(\max(0,Z))$. الحل: الخطوة 1: $\mathbb{E}[Y] = 1/\sqrt{2\pi}$، $\mathbb{E}[Y^2] = \frac{1}{2}\mathbb{E}[Z^2] = \frac{1}{2}$ (لأن النصف فقط). الخطوة 2: $\text{Var} = 0.5 - (0.399)^2 \approx 0.341$. النتيجة: $0.341 \approx$. الربط بالذكاء الاصطناعي: تهيئة He تأخذ تباين ReLU بعين الاعتبار.

مثال (3.15-15).

تفكيك الانحياز/التباين. المعطيات: مُقدّر $\hat{f}$ لمعامل f^*. المطلوب: فكّك خطأ التعميم. الحل: الخطوة 1: $\mathbb{E}[(\hat{f} - f^*)^2] = \underbrace{(\mathbb{E}[\hat{f}] - f^*)^2}_{\text{انحياز}^2} + \underbrace{\text{Var}(\hat{f})}_{\text{تباين}}$. النتيجة: مجموع الانحياز^2 والتباين. الربط بالذكاء الاصطناعي: المفاضلة المحورية في قدرة التعميم (bias-variance tradeoff).

التعريف

dir="ltr"> <div

Definition 1.4.15 (Key bounds). convexity and tail
For g convex, $g(\mathbb{E}[X]) \leq \mathbb{E}[g(X)]$:**Jensen**
For non-negative X, $\mathbb{P}(X \geq a) \leq \mathbb{E}[X]/a$:**Markov**
with mean μ, variance σ^2, $\mathbb{P}(|X - \mu| \geq t) \leq \sigma^2/t^2$:**Chebyshev**
any X.

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq t) \leq \frac{\mathrm{Var}(X)}{t^2}. \tag{3.15}$$

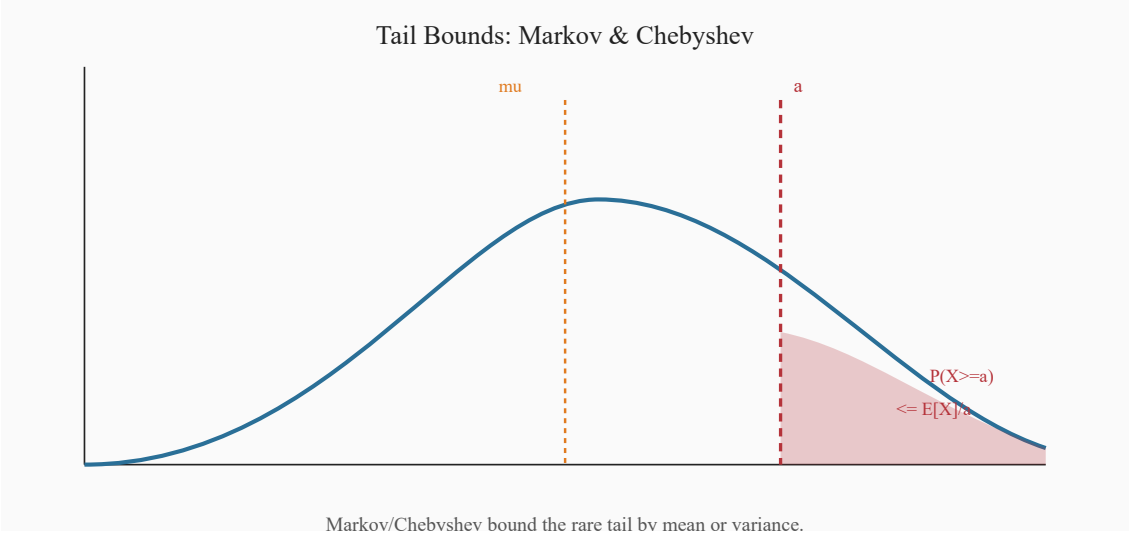
dir="ltr"> <div
a often how about guarantee a into number) single (a variance a turns (3.15) Chebyshev
and Numbers Large of Law the of backbone the — mean its from far strays quantity random
bounds. generalization PAC-style

جدول الرموز

الرمز	الاسم	المعنى
g محدّبة	دالّة محدّبة	$g'' \geq 0$
$\mathbb{P}(X \geq a)$	ذيل الاحتمال	تجاوز العتبة
t	بُعد الانحراف	عن المتوسّط
σ^2	التباين	يقدّر الذيل

رسم توضيحي

<figure> الشكل<figcaption> 3.15: متراجحة تشيبيشِف/ماركوف تُحدّد سقفاً أحمر للذيل $P(X \geq a)$ بمقدار



شكل ٣.١٥: *
متراجحات الذيل

$\mathbb{E}[X]/a$ أو Var/t^2 — لا نحتاج شكل التوزيع كاملاً.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
استخدام جنسن للمحدّبة عكساً	ينعكس الاتجاه	تحقّق من g''
نسيان شرط $X \geq 0$ لماركوف	يبطلها	طبّقها على الموجب
اعتبار الحدّ ضيقاً	هو أسوأ الحالات	قد يكون مُبالغاً

أمثلة محلولة على المتراجحات (15 مثالاً)

مثال (15.4-1).

جنسن للمحدّبة: اللوغاريتم. المعطيات: $g(x) = -\log x$ محدّبة، X موجبة. المطلوب: عبّر عن جنسن. الحل: الخطوة 1: $\mathbb{E}[-\log X] \geq -\log \mathbb{E}[X] \Rightarrow \mathbb{E}[\log X] \leq \log \mathbb{E}[X]$. النتيجة: المتوسّط اللوغاريتمي $\leq$ المتوسّط الحسابي. الربط بالذكاء الاصطناعي: أساس AM-GM وخسارة التباعد.

مثال (15.4-2).

جنسن للمقعّرة: الإنتروبيا. المعطيات: g مقعّرة. المطلوب: اتجاه جنسن. الحل: الخطوة 1: للمقعّرة $\mathbb{E}[g(X)] \leq g(\mathbb{E}[X])$ (عكس المحدّبة). النتيجة: الإنتروبيا لمتوسّط $\geq$ متوسّط الإنتروبيا. الربط بالذكاء الاصطناعي: تقييم التوزيع المتوسّط للنماذج المختلطة.

مثال (15.4-3).

ماركوف على خسارة موجبة. المعطيات: $\ell \geq 0$، $\mathbb{E}[\ell] = 0.1$. المطلوب: $\mathbb{P}(\ell \geq 1)$ كحدّ أعلى. الحل: الخطوة 1: $\mathbb{P}(\ell \geq 1) \leq \mathbb{E}[\ell]/1 = 0.1$. النتيجة: $\leq 10\%$. الربط بالذكاء الاصطناعي: ضمان ألاّ تتجاوز الخسارة حدّاً بكثرة.

مثال (15.4-4).

تشيبيشف: احتمال الانحراف. المعطيات: $\mu = 0$، $\sigma^2 = 4$، $t = 4$. المطلوب: $\mathbb{P}(|X| \geq 4)$. الحل: الخطوة 1: $\leq \sigma^2/t^2 = 4/16 = 0.25$. النتيجة: $\leq 25\%$. الربط بالذكاء الاصطناعي: احتمال أن يكون التدرّج بعيداً عن المتوسّط.

مثال (15.4-5).

تشيبيشف بوحدات الانحراف المعياري. المعطيات: نريد k انحراف معياري. المطلوب: $\mathbb{P}(|X - \mu| \geq k\sigma)$. الحل: الخطوة 1: بـ $t = k\sigma$ نحصل على $\leq 1/k^2$. النتيجة: $\leq 1/k^2$ (مثل $k = 3$ لـ $1/9$). الربط بالذكاء الاصطناعي: كشف الشذوذ بـ 3σ (انظر 14.3-7).

مثال (15.4-6).

كانتِلي (أحادي الجانب). المعطيات: $\mu = 0$، $\sigma^2 = 1$. المطلوب: حدّ $\mathbb{P}(X - \mu \geq t)$. الحل: الخطوة 1: كانتِلي المعكوس: $\mathbb{P}(X - \mu \geq t) \leq \frac{\sigma^2}{\sigma^2 + t^2}$. الخطوة 2: لـ $t = 1$: $\leq 1/2$. النتيجة: ≤ 0.5. الربط بالذكاء الاصطناعي: حدّ أحادي الجانب لزمن الاستجابة الأعلى.

مثال (4.15-7).

تشيبيشِف يقود قانون الأعداد الكبيرة. المعطيات: $\bar{X}_n$ متوسّط n عيّنة i.i.d. بتباين σ^2. المطلوب: حدّ $\mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon)$. الحل: الخطوة 1: $\mathrm{Var}(\bar{X}_n) = \sigma^2/n \to 0 \Rightarrow$ تشيبيشِف؛ $\leq \frac{\sigma^2}{n\varepsilon^2}$. النتيجة: يتقارب في الاحتمال إلى μ. الربط بالذكاء الاصطناعي: تقارب متوسّط دُفعات SGD نحو المتوسّط.

مثال (4.15-8).

ماركوف على زمن الخدمة. المعطيات: $\mathbb{E}[T] = 0.5$ ث، $T \geq 0$. المطلوب: $\mathbb{P}(T \geq 2)$. الحل: الخطوة 1: $\leq 0.5/2 = 0.25$. النتيجة: $\leq 25\%$. الربط بالذكاء الاصطناعي: ضمان مستوى الخدمة (SLA) لزمن الاستجابة.

مثال (4.15-9).

جنسن على تباعد KL. المعطيات: $\mathrm{KL}(p\|q) = \mathbb{E}_p[\log(p/q)]$. المطلوب: بيّن $\mathrm{KL} \geq 0$. الحل: الخطوة 1: $-\mathrm{KL} = \mathbb{E}_p[\log(q/p)] \leq \log \mathbb{E}_p[q/p] = \log 1 = 0$. النتيجة: $\mathrm{KL} \geq 0$ (بجنسن على اللوغاريتم المقعّر). الربط بالذكاء الاصطناعي: KL غير سالب = أساس VAE/ELBO.

مثال (4.15-10).

حدّ لمعيار التدرّج. المعطيات: $\mathbb{E}[\|\nabla\|^2] = G^2$. المطلوب: $\mathbb{P}(\|\nabla\|^2 \geq 4G^2)$. الحل: الخطوة 1: ماركوف: $\leq G^2/(4G^2) = 0.25$. النتيجة: $\leq 25\%$ لضخامة التدرّج المضاعفة. الربط بالذكاء الاصطناعي: ضبط معدّل التعلّم لتفادي قفزات التدرّج الكبيرة.

مثال (4.15-11).

تشيبيشِف لخطأ مونت كارلو. المعطيات: تقدير $\hat{I}$ بـ n عيّنة، تباين σ^2. المطلوب: حدّ الخطأ باحتمال 95%. الحل: الخطوة 1: $\mathbb{P}(|\hat{I} - I| \geq \varepsilon) \leq \sigma^2/(n\varepsilon^2)$؛ لـ 95% نأخذ $\varepsilon \approx \sigma/\sqrt{0.05n}$. النتيجة: خطأ $\mathcal{O}(1/\sqrt{n})$. الربط بالذكاء الاصطناعي: تقدير توقعات الخسارة بأخذ عيّنات.

مثال (4.15-12).

جنسن لتباعد ف-ديفرجنس. المعطيات: f-divergence محدّب في q. المطلوب: استنتج الخاصية. الحل: الخطوة 1: المحدّبية تضمن أن التباعد يصل صفراً عند التطابق فقط ويتقعّر حوله. النتيجة: خاصية المسافة غير المتماثلة. الربط بالذكاء الاصطناعي: قياس الاختلاف بين توزيعات النموذج والحقيقة.

مثال (4.15-13).

متراجحة هويفدينغ (تمهيد). المعطيات: $X_i \in [a,b]$ مستقلّة. المطلوب: حدّ $\mathbb{P}(|\bar{X} - \mu| \geq \varepsilon)$ أقوى من تشيبيشِف. الحل: الخطوة 1: هويفدينغ: $\leq 2\exp(-2n\varepsilon^2/(b-a)^2)$ (أسّي لا تربيعي). النتيجة: تقارب أسّي.

الربط بالذكاء الاصطناعي: حدود تركيز (concentration) تأتي لاحقاً في الفصل 17.

مثال (14-4.15).

تشيبيشف لكشف الشذوذ. المعطيات: ميزة بـ $\mu = 10$، $\sigma = 2$. المطلوب: متى نعتبر نقطة شاذة بـ 95%؟ الحل: الخطوة 1: نريد $1/k^2 = 0.05 \Rightarrow k \approx 4.47$ انحراف. الخطوة 2: العتبة $10 \pm 4.47 \times 2 = 10 \pm 8.94$. النتيجة: خارج $[1.06, 18.94]$ شاذ إحصائياً. الربط بالذكاء الاصطناعي: كشف شذوذ بمبدأ تشيبيشف المحافظ.

مثال (15-4.15).

اتحاد الحدود (Union bound) مع ماركوف. المعطيات: m مقاييس $X_j \geq 0$ كلٌّ بمتوسّط $\leq c/m$. المطلوب: $\mathbb{P}(\exists j : X_j \geq a)$. الحل: الخطوة 1: $\leq \sum_j \mathbb{P}(X_j \geq a) \leq \sum_j (c/m)/a = c/a$. النتيجة: حدّ اتحاد عبر ماركوف. الربط بالذكاء الاصطناعي: حدود خطأ متعدّد الفرضيات في اختبار النماذج.

التعريف

dir="ltr"> <div
is $A \in \mathbb{R}^{d \times d}$ matrix symmetric A **definite). / semidefinite (Positive 1.5.15 Definition positive** is It .$x \in \mathbb{R}^d$ all for $x^\top A x \geq 0$ fi ,$A \succcurlyeq 0$ written ,**(PSD) semidefinite positive** .$x \neq 0$ all for $x^\top A x > 0$ fi ,$A \succ 0$,**(PD) definite**

$$A \succcurlyeq 0 \iff \mathbf{x}^\top A \mathbf{x} \geq 0 \ \forall \mathbf{x} \in \mathbb{R}^d. \tag{4.15}$$

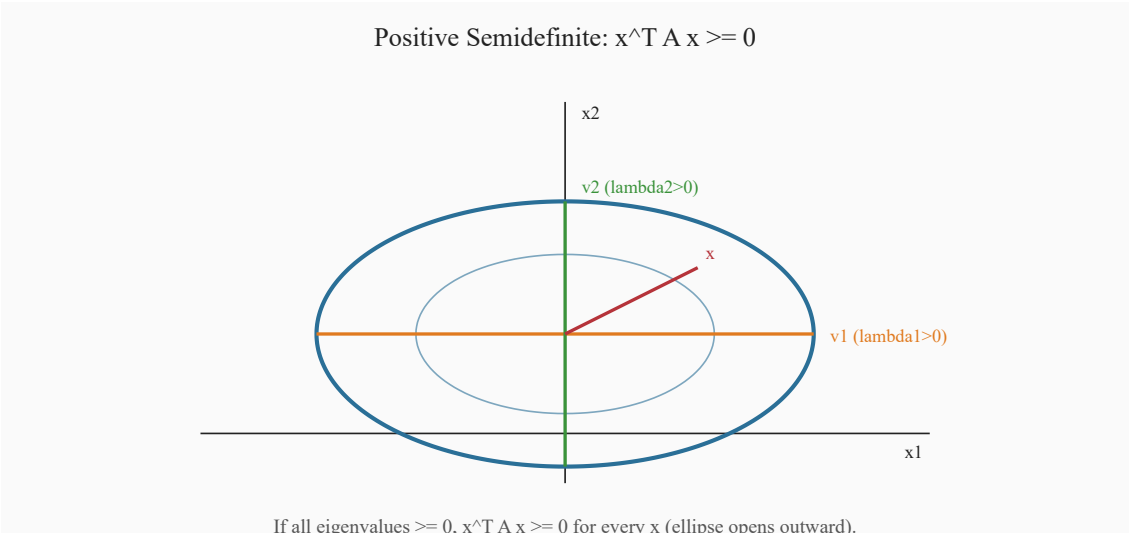
dir="ltr"> <div
a of Hessian the as appears that bowl of shape same the is (4.15) form quadratic The structure PSD recognizing so — information Fisher the and matrix, covariance the loss, convex
valid. is distribution a and convex is landscape optimization an whether immediately you tells

جدول الرموز

الرمز	الاسم	المعنى
$A \succcurlyeq 0$	موجبة نصف التحديد	$x^\top A x \geq 0$
$A \succ 0$	موجبة التحديد	$x^\top A x > 0$ ($x \neq 0$ لـ)
λ_i	قيمة ذاتية	كلها ≥ 0 لـ PSD
$x^\top A x$	صيغة تربيعية	«وعاء» التوزيع/الخسارة

رسم توضيحي

<figure> الشكل<figcaption> 4.15: المستوى المستوي $x^\top A x = 1$ لـ PSD هو إهليلج مفتوح للخارج. القيم الذاتية الموجبة كلها تجعل $x^\top A x \geq 0$ لأي متجه x</figcaption>. </figure>



شكل ١٥.٤: *
المصفوفة الموجبة نصف التحديد

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«كل عناصر $A > 0$» $\Rightarrow$ PSD	خطأ (مثال مضادّ)	افحص القيم الذاتية
الخلط بين متماثلة وPSD	PSD تشترط التماثل	تحقّق $A = A^\top$
اعتبار المحدّد الموجب كافياً	يحتاج كل الفرعية	استخدم شروط سيلفستر

أمثلة محلولة على المصفوفات الموجبة (15 مثالاً)

مثال (15.5-1).

إثبات PSD بصيغة تربيعية. المعطيات: $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$. المطلوب: هل هي PSD؟ الحل: الخطوة 1: $x^\top Ax = 2x_1^2 + 2x_1x_2 + 2x_2^2 = (x_1 + x_2)^2 + x_1^2 + x_2^2 \geq 0$. النتيجة: PSD (بل PD). الربط بالذكاء الاصطناعي: تغاير ميزتين مترابطتين إيجابياً.

مثال (15.5-2).

القيم الذاتية الموجبة تكفي. المعطيات: A متماثلة بقيم ذاتية $3, 1, 0.5$. المطلوب: قرّر نوعها. الحل: الخطوة 1: كلها $> 0 \Rightarrow A \succ 0$. النتيجة: موجبة التحديد (PD). الربط بالذكاء الاصطناعي: مصفوفة تغاير منتظمة قابلة للعكس.

مثال (15.5-3).

مصفوفة غرام موجبة نصف التحديد. المعطيات: $K = XX^\top$ لأي X. المطلوب: أثبت $K \succcurlyeq 0$. الحل: الخطوة 1: $v^\top Kv = v^\top XX^\top v = \|X^\top v\|^2 \geq 0$. النتيجة: غرام دوماً PSD. الربط بالذكاء الاصطناعي: نواة غاوسية (kernel matrix) PSD.

مثال (5.15-4).

مصفوفة التغاير PSD. المعطيات: $\Sigma = \mathbb{E}[(X-\mu)(X-\mu)^\top]$. المطلوب: أثبت PSD. الحل: الخطوة 1: $v^\top \Sigma v = \mathbb{E}[(v^\top(X-\mu))^2] \geq 0$. النتيجة: تغاير أي توزيع PSD. الربط بالذكاء الاصطناعي: أساس كل تحليل تغاير (انظر 3.15).

مثال (5.15-5).

مجموع PSD موجب نصف التحديد. المعطيات: $A, B \succcurlyeq 0$. المطلوب: هل $A+B \succcurlyeq 0$؟ الحل: الخطوة 1: $x^\top(A+B)x = x^\top Ax + x^\top Bx \geq 0+0$. النتيجة: نعم. الربط بالذكاء الاصطناعي: جمع شروط مسبقة/تغايرات يحفظ الصلاحية.

مثال (5.15-6).

$A^\top A$ موجبة نصف التحديد. المعطيات: أي $A \in \mathbb{R}^{m\times n}$. المطلوب: أثبت $A^\top A \succcurlyeq 0$. الحل: الخطوة 1: $x^\top A^\top Ax = \|Ax\|^2 \geq 0$. النتيجة: دوماً PSD. الربط بالذكاء الاصطناعي: $J^\top J$ في غاوس-نيوتن (انظر 6.9، 7.15).

مثال (5.15-7).

معكوس الموجبة التحديد موجب التحديد. المعطيات: $A \succ 0$. المطلوب: هل $A^{-1} \succ 0$؟ الحل: الخطوة 1: قيم A^{-1} هي مقلوب قيم A (موجبة) $\Rightarrow A^{-1} \succ 0$. النتيجة: نعم. الربط بالذكاء الاصطناعي: مصفوفة الدقّة (precision) لموزّع غاوسي PD.

مثال (5.15-8).

وجود تشوليسكي يكافئ PD. المعطيات: $A \succ 0$. المطلوب: اربط بـ $LL^\top$. الحل: الخطوة 1: $A \succ 0 \Leftrightarrow$ يوجد L مثلثي سفلي $A = LL^\top$. النتيجة: التحليل ممكن. الربط بالذكاء الاصطناعي: أخذ عيّنات وأخمصة المصفوفات (13-6.14).

مثال (5.15-9).

المستوى المستوي كإهليلج. المعطيات: $A = \begin{pmatrix} 4 & 0 \\ 0 & 1 \end{pmatrix}$. المطلوب: شكل $x^\top Ax = 1$. الحل: الخطوة 1: $4x_1^2 + x_2^2 = 1 \Rightarrow$ إهليلج نصف محاوره $1/2$ و1. النتيجة: إهليلج أفقي مسطّح. الربط بالذكاء الاصطناعي: محيط كثافة غاوسية ثنائية (14-6.14).

مثال (10-5.15).

كشف مصفوفة ليست PSD. المعطيات: $A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$. المطلوب: هل PSD؟ الحل: الخطوة 1: القيم الذاتية $3, -1$ (أثر 2، محدّد -3) $\Rightarrow$ قيمة سالبة. الخطوة 2: بـ $x = (1, -1)$: $x^\top Ax = 1 - 2 - 2 + 1 = -2 < 0$. النتيجة: ليست PSD. الربط بالذكاء الاصطناعي: تغاير «مقدّر سيّئاً» قد يفقد الصلاحية.

مثال (11-5.15).

هيسيّة تربيعية محدّبة PSD. المعطيات: $f(x) = \frac{1}{2}x^\top Qx$، $Q \succ 0$. المطلوب: هل f محدّبة؟ الحل: الخطوة 1: $\nabla^2 f = Q \succcurlyeq 0 \Rightarrow$ محدّبة (وعميقة عند $Q \succ 0$). النتيجة: نعم. الربط بالذكاء الاصطناعي: خسارة المربعات الصغرى محدّبة (أساس التحسين).

مثال (12-5.15).

معلومات فيشر PSD (تمهيد). المعطيات: $I(\theta) = \mathbb{E}[\nabla \ell \, \nabla \ell^\top]$. المطلوب: أثبت PSD. الحل: الخطوة 1: كـ $A^\top A$ (مع $A = \nabla \ell^\top$) $\Rightarrow$ PSD. النتيجة: PSD. الربط بالذكاء الاصطناعي: أساس التدرّج الطبيعي (7.15).

مثال (13-5.15).

لابلاسيان الرسم البياني PSD. المعطيات: $L = D - W$ لمخطّط. المطلوب: أثبت $L \succcurlyeq 0$. الحل: الخطوة 1: $x^\top Lx = \frac{1}{2}\sum_{(i,j)} w_{ij}(x_i - x_j)^2 \geq 0$. النتيجة: PSD. الربط بالذكاء الاصطناعي: GNN وانتشار على الرسوم البيانية.

مثال (14-5.15).

مصفوفة إسقاط PSD. المعطيات: $P = uu^\top$، $\|u\| = 1$. المطلوب: أثبت PSD ومرتبتها. الحل: الخطوة 1: $x^\top Px = (u^\top x)^2 \geq 0$؛ المرتبة 1. النتيجة: PSD رتبة 1. الربط بالذكاء الاصطناعي: إسقاط الميزات على اتجاه رئيسي (PCA).

مثال (15-5.15).

تنظيم لجعلها PD. المعطيات: Σ PSD (قد تكون مفردة). المطلوب: اجعلها قابلة للعكس بأمان. الحل: الخطوة 1: $\Sigma_\lambda = \Sigma + \lambda I$، $\lambda > 0 \Rightarrow$ كل القيم الذاتية $> 0 \Rightarrow$ PD. النتيجة: $\Sigma_\lambda \succ 0$. الربط بالذكاء الاصطناعي: تقنية «تصلّب» التغاير في الخليط/GMM.

التعريف

dir="ltr"> <div

Definition 1.6.15 (Schur complement). For a block symmetric matrix with $A \succ 0$,

$$\begin{pmatrix} A & B \\ B^\top & C \end{pmatrix} \succcurlyeq 0 \iff C - B^\top A^{-1} B \succcurlyeq 0.$$

The term $S = C - B^\top A^{-1} B$ is the **Schur complement** of A. It also gives the conditional covariance of a Gaussian (§6.14) and the block-inverse formula.

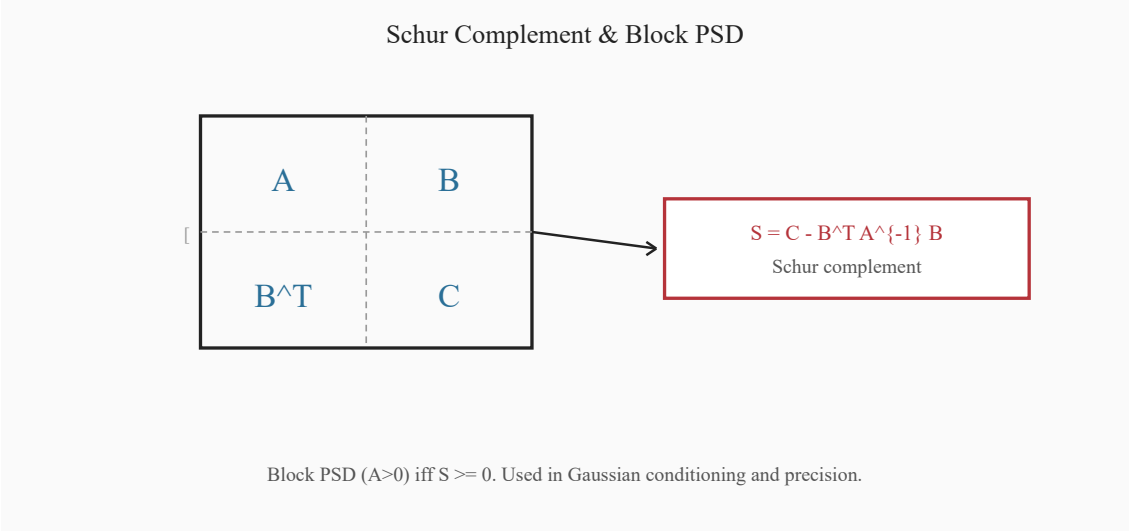
$$\begin{pmatrix} A & B \\ B^\top & C \end{pmatrix} \succcurlyeq 0 \iff C - B^\top A^{-1} B \succcurlyeq 0 \quad (A \succ 0). \tag{5.15}$$

The Schur complement is the algebraic engine behind Gaussian conditioning (§6.14) and the block-inverse formula. It also gives the conditional covariance of a Gaussian: this is exactly why the complement appears in both the PD-ness proof and in graphical models.

جدول الرموز

الرمز	الاسم	المعنى
S	المكمّل الشورّي	$C - B^\top A^{-1} B$
$A \succ 0$	كتلة معكوسة	شرط الاستخدام
$\begin{pmatrix} A & B \\ B^\top & C \end{pmatrix}$	مصفوفة كتلية	تغاير مشترك
block-inverse	معكوس كتلي	يستخدم S

رسم توضيحي

<figure>


<figcaption>الشكل ٥.١٥: لمصفوفة كتلية متماثلة، الشرط $S = C - B^\top A^{-1} B \succcurlyeq 0$ يكافئ كون الكتلة</figcaption>

شكل ٥.١٥: *
المكمّل الشورّي

الكتلية PSD. يظهر هذا في التغاير الشرطي الغاوسي وصيغة المعكوس الكتلي.</figcaption>
</figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
استخدام شورّ بلا $A \succ 0$	الشرط يفشل في غير المتماثلة	تحقّق من A أولاً
خلط $B^\top$ مع B	يبطل الصيغة	حافظ على التماثل
نسيان S في التغاير الشرطي	هو التباين الشرطي	

أمثلة محلولة على المكمّل الشورّي (15 مثالاً)

مثال (15.6-1).

حساب المكمّل الشورّي. المعطيات: $A = [2]$, $B = [1]$, $C = [1]$ (كتل 1×1). المطلوب: S وقرار PSD. الحل: الخطوة 1: $S = 1 - 1 \cdot (1/2) \cdot 1 = 1 - 0.5 = 0.5 \geq 0$. النتيجة: الكتلة الكلية PSD. الربط بالذكاء الاصطناعي: حالة ثنائية البُعد من التغاير.

مثال (15.6-2).

التباين الشرطي الغاوسي. المعطيات: تغاير كلي $\begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$. المطلوب: التباين الشرطي لـ $X_1 \mid X_2$. الحل: الخطوة 1: بـ (15.5) التباين الشرطي = $S = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$. النتيجة: S هو التباين الشرطي. الربط بالذكاء الاصطناعي: تصفية كالمان (14.6-9) تعتمده.

مثال (15.6-3).

مصفوفة الدقّة الكتلية. المعطيات: Σ^{-1} لكتلة Σ. المطلوب: عبّر عن الكتل عبر شورّ. الحل: الخطوة 1: $\Sigma^{-1} = \begin{pmatrix} \Sigma_{11}^{-1} + S^{-1}\cdots & -S^{-1}\Sigma_{12}\Sigma_{22}^{-1} \\ \cdots & S^{-1} \end{pmatrix}$، S مكمّل Σ_{22}. النتيجة: صيغة المعكوس الكتلي. الربط بالذكاء الاصطناعي: التحليل الدقيق (precision matrix) في GMRF.

مثال (15.6-4).

تحليل تشوليسكي الكتلي. المعطيات: $A \succ 0$، نريد $M = LL^\top$. المطلوب: علاقة الكتل بـ S. الحل: الخطوة 1: $L = \begin{pmatrix} L_{11} & 0 \\ B^\top A^{-1} L_{11} & L_{22} \end{pmatrix}$ حيث $S = L_{22}L_{22}^\top$. النتيجة: المكمّل يظهر في الكتلة السفلية. الربط بالذكاء الاصطناعي: عامل تشوليسكي متدرّج للمصفوفات الكبيرة.

مثال (15.6-5).

تبييض عبر المكمّل. المعطيات: تغاير كلي. المطلوب: اربط التبييض (14.6-6) بالمكمّل. الحل: الخطوة 1: التبييض $W = \Sigma^{-1/2}$، كتلياً يستخدم S لفكّ الارتباط. النتيجة: تعامد المكوّنات بعده. الربط بالذكاء الاصطناعي: تبييض البيانات قبل النماذج الخطّية.

مثال (6-6.15).

ماهالانوبيس كصيغة تربيعية. المعطيات: $\Sigma \succ 0$، $D^2 = (x-\mu)^\top \Sigma^{-1}(x-\mu)$. المطلوب: بيّن أنها مسافة (PSD). الحل: الخطوة 1: $\Sigma^{-1} \succ 0$ (7-5.15) $\Rightarrow$ الصيغة التربيعية ≥ 0. النتيجة: مربّع مسافة صالح. الربط بالذكاء الاصطناعي: كشف الشذوذ بمسافة ماهالانوبيس (5-6.14).

مثال (7-6.15).

كتلة قُطرية PSD. المعطيات: $M = \operatorname{diag}(A, C)$ مع $A, C \succcurlyeq 0$. المطلوب: هل $M \succcurlyeq 0$؟ الحل: الخطوة 1: $B = 0 \Rightarrow S = C \succcurlyeq 0 \Rightarrow$ نعم. النتيجة: الكتل القُطرية PSD كلّياً. الربط بالذكاء الاصطناعي: ميزات مستقلّة $\Rightarrow$ تغوار قُطري.

مثال (8-6.15).

جداء كرونكر لـ PSD. المعطيات: $A, B \succcurlyeq 0$. المطلوب: هل $A \otimes B \succcurlyeq 0$؟ الحل: الخطوة 1: قيم $A \otimes B$ هي جداء قيم A وقيم B (كلها ≥ 0). النتيجة: نعم. الربط بالذكاء الاصطناعي: تغوار مُنتج كانيشي (Kronecker) في النماذج الموحّدة.

مثال (9-6.15).

فحص سيلفستر للمقدمات الرائدة. المعطيات: $A = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$. المطلوب: هل PD عبر سيلفستر؟ الحل: الخطوة 1: المقدّمة [1]=2>0، المحدّد الكلي $2 - 1 = 1 > 0 \Rightarrow$ PD. النتيجة: PD. الربط بالذكاء الاصطناعي: فحص سريع لصلاحية تغوار مقدّر.

مثال (10-6.15).

اشتقاق شرط التغوار الغاوسي (4-6.14). المعطيات: كثافة مشتركة غاوسية. المطلوب: أعد اشتقاق المتوسّط/التباين الشرطي. الحل: الخطوة 1: بتكامل الغاوسي المكمّل يظهر S كتباين شرطي والمعامل $\Sigma_{12}\Sigma_{22}^{-1}$ كمنحدّر. النتيجة: يطابق 4-6.14. الربط بالذكاء الاصطناعي: توحيد الاشتقاق عبر شورّ لكل النماذج الغاوسية.

مثال (11-6.15).

تغوار عمليات غاوسية PSD. المعطيات: نواة $K(x, x') = \exp(-\|x - x'\|^2/2)$. المطلوب: لماذا مصفوفة النواة PSD؟ الحل: الخطوة 1: نواة غاوسية = «نواة موزّع» $\Rightarrow$ مصفوفة غرام (3-5.15) $\Rightarrow$ PSD. النتيجة: PSD. الربط بالذكاء الاصطناعي: GP و SVM والانتباه النووي.

مثال (6.15-12).

ريدج: $\Sigma + \lambda I$ المعطيات: PD. $X^\top X$، PSD نضيف λI. المطلوب: أثبت قابلية العكس. الحل: الخطوة 1: $X^\top X + \lambda I \succ 0$ (15-5.15) $\Rightarrow$ معكوس موجود. النتيجة: الحل المُنظّم مستقرّ. الربط بالذكاء الاصطناعي: انحدار ريدج/التسوّي (ridge) قابل للحل دوماً.

مثال (6.15-13).

الجذر المربّع لمصفوفة PSD. المعطيات: $A \succcurlyeq 0$ بقيم ذاتية λ_i. المطلوب: عرّف $A^{1/2}$. الحل: الخطوة 1: $A = U\Lambda U^\top \Rightarrow A^{1/2} = U\Lambda^{1/2}U^\top$ (جذور القيم ≥ 0). النتيجة: معرّفة جيّداً. الربط بالذكاء الاصطناعي: تبييض $A^{-1/2}$ وأخذ عيّنات (6-6.14).

مثال (6.15-14).

لوغاريتم المحدّد لتوزيع PSD. المعطيات: كثافة غاوسية فيها $|\Sigma|^{1/2}$. المطلوب: لماذا $|\Sigma| > 0$ لد PD؟ الحل: الخطوة 1: $|\Sigma| = \prod \lambda_i > 0$ عند كل $\lambda_i > 0$. النتيجة: التطبيع معرّف. الربط بالذكاء الاصطناعي: شرطة التدفّقات/GMM يتطلّب $|\Sigma| > 0$.

مثال (6.15-15).

إسقاط أقرب PSD. المعطيات: مصفوفة M غير متماثلة/غير PSD. المطلوب: اجعلها PSD. الحل: الخطوة 1: خذ $A = (M + M^\top)/2$ ثم اضبط قيمها الذاتية السالبة إلى 0 (إسقاط طيفي). النتيجة: أقرب PSD بمعيار فريبنيوس. الربط بالذكاء الاصطناعي: تصحيح تغوار مُقدّر بانحراف رقمي.

التعريف

dir="ltr"> <div

Definition 6.7.15 (Fisher & information Cramér–Rao). For a parametric family $p_\theta(x)$, the **Fisher information** is

$$I(\theta) = \mathbb{E}_\theta\left[\nabla_\theta \log p_\theta \, \nabla_\theta \log p_\theta^\top\right],$$

PSD. always any unbiased estimator $\hat{\theta}$, the **Cramér–Rao bound** states

$$\mathrm{Cov}(\hat{\theta}) \succcurlyeq I(\theta)^{-1}.$$

$$\mathrm{Cov}(\hat{\theta}) \succcurlyeq I(\theta)^{-1}, \qquad I(\theta) = \mathbb{E}[\nabla_\theta \ell \, \nabla_\theta \ell^\top]. \tag{6.15}$$

dir="ltr"> <div

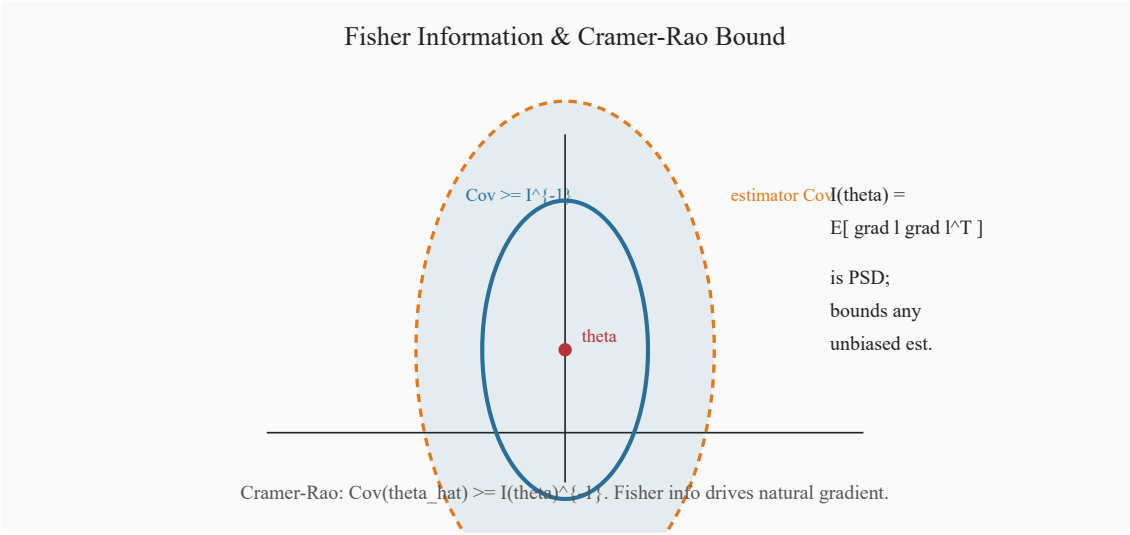
Equation (6.15) ties together: the covariance matrix of any estimator (§3.15), the inverse of a PSD matrix (§5.15), and squared expected gradients (§2.15). It is the information-geometric limit of learning.

جدول الرموز

الرمز	الاسم	المعنى
$I(\theta)$	معلومات فيشر	يقيس حساسية اللوغاريتم
$\ell = \log p_\theta$	اللوغاريتم الاحتمالي	نقطة الصيد
$I(\theta)^{-1}$	حدّ التباين	أصغر تباين ممكن
CRB	كرامير–راو	أسفل حدّ التغوار

رسم توضيحي

<figure> الشكل<figcaption> 7.15: معلومات فيشر $I(\theta)$ (PSD) تُحدّد أصغر تباين ممكن لمُقدّر غير منحاز عبر



شكل ٦.١٥: *
معلومات فيشر وكرامير-راو

$I(\theta)^{-1}$ (إهليلج داخلي). سحابة المُقدّر (خارجي) لا يمكن أن تضيق داخل هذا الحدّ.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الخلط بين I و Σ	مفهومان مختلفان	I لمعلومات المعامل
نسيان شرط «غير منحاز»	الحدّ يُلغى	تحقّق الانحياز
اعتبار I^{-1} تبايناً فعلياً	هو حدّ أسفل فقط	المُقدّر قد يكون أسوأ

أمثلة محلولة على التطبيقات (15 مثالاً)

مثال (15.7-1).

معلومات فيشر لبرنولي. المعطيات: $X \sim \mathrm{Bern}(p)$، المعامل p. المطلوب: $I(p)$. الحل: الخطوة 1: $\ell = x\log p + (1-x)\log(1-p)$؛ الخطوة 2: $\partial_p \ell = (x-p)/(p(1-p))$. $\mathbb{E}[(\partial_p \ell)^2] = \frac{\mathrm{Var}(X)}{p^2(1-p)^2} = \frac{p(1-p)}{p^2(1-p)^2} = \frac{1}{p(1-p)}$. النتيجة: $I(p) = 1/(p(1-p))$. الربط بالذكاء الاصطناعي: دقّة تقدير احتمال تصنيف تتناسب عكسياً مع $p(1-p)$.

مثال (15.7-2).

معلومات فيشر لغاوسي بالمتوسّط. المعطيات: $X \sim \mathcal{N}(\mu, \sigma^2)$ معروف σ^2. المطلوب: $I(\mu)$. الحل: الخطوة 1: $\partial_\mu \ell = (x-\mu)/\sigma^2$، $\mathbb{E}[(\partial_\mu \ell)^2] = 1/\sigma^2$. النتيجة: $I(\mu) = 1/\sigma^2$. الربط بالذكاء الاصطناعي: تشتت أقل $\Rightarrow$ معلومات أكثر عن μ.

مثال (15.7-3).

معلومات فيشر لغاوسي بالتباين. المعطيات: $X \sim \mathcal{N}(0, \sigma^2)$. المطلوب: $I(\sigma^2)$. الحل: الخطوة 1: $\partial_{\sigma^2}\ell = \frac{1}{2}(\frac{x^2}{\sigma^4} - \frac{1}{\sigma^2})$؛ نربّع ونأخذ المتوقّع: $I = 1/(2\sigma^4)$. النتيجة: $I(\sigma^2) = 1/(2\sigma^4)$. الربط بالذكاء الاصطناعي: تقدير التباين أصعب (معلومات أقلّ).

مثال (15.7-4).

حدّ كرامير–راو لمُقدّر غير منحاز. المعطيات: $I(\mu) = 1/\sigma^2$. المطلوب: أصغر تباين ممكن لـ $\hat{\mu}$ غير منحاز. الحل: الخطوة 1: $\mathrm{Var}(\hat{\mu}) \geq I^{-1} = \sigma^2$. الخطوة 2: متوسّط العيّنة يحقّقه $\mathrm{Var} = \sigma^2/n$ لأخذ n — هنا $n = 1$). النتيجة: الحدّ σ^2 (لكل عيّنة). الربط بالذكاء الاصطناعي: متوسّط الدفعة هو المُقدّر الفعّال.

مثال (15.7-5).

كرامير–راو متعدّد المتغيّرات. المعطيات: $\theta \in \mathbb{R}^d$، $I(\theta)$ مصفوفة. المطلوب: صيغة الحدّ. الحل: الخطوة 1: $\mathrm{Cov}(\hat{\theta}) \succcurlyeq I(\theta)^{-1}$ (مصفوفات، (15.6))). النتيجة: حدّ المصفوفة. الربط بالذكاء الاصطناعي: تقدير متجهّة المعاملات في الشبكات.

مثال (15.7-6).

PCA كتحليل قيم ذاتية للتغوار. المعطيات: Σ تغوار البيانات. المطلوب: اتجاه أكبر تباين. الحل: الخطوة 1: القيمة الذاتية الأكبر لـ Σ والمتجه الذاتي الموافق هما الاتجاه (15.5-2). الخطوة 2: نُسقِط البيانات عليه لاختزال البُعد. النتيجة: المحور الرئيسي. الربط بالذكاء الاصطناعي: اختزال البُعد وتصوير التمثيلات.

مثال (15.7-7).

PCA عبر SVD (ربط الفصل 4). المعطيات: بيانات موسّطة X. المطلوب: اربط PCA بـ SVD. الحل: الخطوة 1: $\Sigma = \frac{1}{n}X^\top X = V\frac{D^2}{n}V^\top$؛ أعمدة V هي المتجهات الذاتية. النتيجة: PCA = SVD لـ X. الربط بالذكاء الاصطناعي: اختزال البُعد عبر SVD (ch04).

مثال (15.7-8).

المُميِّز الخطّي لفِشر (LDA). المعطيات: صنفان بـ μ_1, μ_2 وتغوار مشترك Σ. المطلوب: اتجاه الإسقاط الأمثل. الحل: الخطوة 1: $w \propto \Sigma^{-1}(\mu_1 - \mu_2)$ (يعظّم نسبة بين/داخل التباين). النتيجة: اتجاه فيشر. الربط بالذكاء الاصطناعي: مصنّف LDA الكلاسيكي.

مثال (15.7-9).

قُطرَة التغوار بالإسقاط. المعطيات: نُسقِط على u بوحدة الطول. المطلوب: التباين المتبقّي. الحل: الخطوة 1: $\mathrm{Var}(u^\top X) = u^\top \Sigma u$ (15.3-12). الخطوة 2: يُعظَّم عند المتجه الذاتي الأكبر (15.5). النتيجة: قيمة ذاتية. الربط بالذكاء الاصطناعي: اختيار مكوّن PCA يقلّل فقدان المعلومة.

مثال (15.7-10).

معلومات فيشر = هيسيّة متوقّعة. المعطيات: $\ell = \log p_\theta$. المطلوب: اربط $I(\theta)$ بهيسيّة ℓ. الحل: الخطوة 1: $-I(\theta) = \mathbb{E}[\nabla^2 \ell]$ (بتكامل بالأجزاء على التوزيع). النتيجة: $I = -\mathbb{E}[H_\ell]$. (PSD) الربط بالذكاء الاصطناعي: الهيسيّة المتوقّعة تُقرّب معلومات فيشر في التدرّج الطبيعي.

مثال (15.7-11).

شرطة جيفريز السابقة. المعطيات: $p(\theta) \propto \sqrt{\det I(\theta)}$. المطلوب: لماذا الجذر؟ الحل: الخطوة 1: $\det I(\theta)$ مقياس حجم المعلومات؛ جذره يعطي كثافة متغيّرات معينة. النتيجة: شرطة جيفريز (غير مسبقة المعلومات). الربط بالذكاء الاصطناعي: تحديد الشروط المسبقة بايزياً بتوازن المعلومة.

مثال (15.7-12).

التدرّج الطبيعي يستخدم I^{-1}. المعطيات: تحديث المعامل θ. المطلوب: اربط بالمصفوفة الموجبة. الحل: الخطوة 1: خطوة طبيعية $\Delta\theta \propto I(\theta)^{-1}\nabla L$؛ I^{-1} PD (15.5-7) $\Rightarrow$ اتجاه محِلّ. النتيجة: تحديث في «فضاء المعلومة». الربط بالذكاء الاصطناعي: تدرّج طبيعي/آدم المُعلَم بالفيشر (NGD, K-FAC).

مثال (15.7-13).

هيسيّة غاوس-نيوتن. المعطيات: PSD $L = \frac{1}{2}\|r(\theta)\|^2$. المطلوب: هل هيسيّة GN موجبة نصف التحديد؟ الحل: الخطوة 1: $H_{GN} = J^\top J \succcurlyeq 0$ (15.5-6) — دوماً PSD بخلاف الهيسيّة الحقيقية. النتيجة: نعم. الربط بالذكاء الاصطناعي: استقرار غاوس-نيوتن في مربّعات صغرى غير خطّية (6.9).

مثال (14-7.15).

حدّ ELBO وتحدّب. المعطيات: $\log p(x) \geq \mathbb{E}_q[\log p(x,z) - \log q(z)]$. المطلوب: اربط بالمتراجحات (4.15). الحل: الخطوة 1: ELBO هو متوقّع (LOTUS) يُحدّ بالمتغير؛ جنسن يُعطي الحدّ السفلي. النتيجة: التقارب نحو الحدّ الأعلى. الربط بالذكاء الاصطناعي: VAE والاستدلال المتغير.

مثال (15-7.15).

تغوار ميزات CNN وتبييضها. المعطيات: Σ تغوار ميزات الشبكة. المطلوب: خطّة لتقليل الارتباط. الحل: الخطوة 1: حلّل $\Sigma = U\Lambda U^\top$ (2-5.15)؛ طبّق $W = \Lambda^{-1/2}U^\top$ (تبييض، 13-6.15). الخطوة 2: الميزات المُبيّضة لها تغوار قُطري الوحدة. النتيجة: ميزات غير مترابطة. الربط بالذكاء الاصطناعي: تسريع التدريب عبر إزالة التكرار بين الميزات.

خيط الفصل

ربطنا ثلاث طبقات: (1) المتوقّع/التباين كتكامل LOTUS (1.15)–(2.15) يستندان إلى تكامل ليبيسغ–ستيلتjes (7.10) ودفع $\mathbb{P}_X$ (2.13)؛ (2) المتراجحات (3.15) تحوّل لحظة واحدة إلى ضمان ذيلي بلا شكل كامل؛ (3) المصفوفات الموجبة (4.15)–(5.15) هي الهندسة نفسها التي ظهرت في القيم الذاتية (4)، و$J^\top J$ (6.9)، والتحسين المحدّب (20+). كل أداة هنا تُعيد استخدام بُنية سبق شرحها.

جسور الكتاب

المفهوم	من الفصل	الاستخدام هنا
$\int x\,dF_X$	10 (7.10) / 13 (5.13)	تعريف المتوقّع
$\mathbb{P}_X(B) = \mathbb{P}(X^{-1}(B))$	13 (2.13)	التوزيع كدفع
القيم الذاتية والتحليل $U\Lambda U^\top$	4 (التحليل/SVD)	PSD و PCA
$J^\top J$ والهيسيّة	9 (6.3/9.9)	GN موجب، فيشر
التحسين المحدّب	+20	الهيسيّة PSD ⇒ عمق

هذه الجسور تُبقي الكتاب متّصلاً: الفصل 16 سينتقل إلى الاحتمال الشرطي المتقدّم، بايز، والحقول العشوائية، حيث تُستخدم كل هذه الأدوات.

١. أثبت LOTUS للمنفصل: $\mathbb{E}[g(X)] = \sum g(x_k)p(x_k)$.

٢. لـ $X \sim \mathrm{Bin}(n,p)$ استخدم LOTUS لإيجاد $\mathbb{E}[X(X-1)]$ ثم التباين.

٣. أثبت $\mathrm{Var}(aX+b) = a^2\mathrm{Var}(X)$.

٤. لـ X, Y مستقلّة أثبت $\mathrm{Var}(X-Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$.

٥. بجنسن أثبت $\mathbb{E}[1/X] \geq 1/\mathbb{E}[X]$ لـ $X > 0$؟ (ناقش الشرط — خطأ! بيّن السبب عبر مثال).

٦. طبّق تشيبيشِف لإيجاد n بحيث $\mathbb{P}(|\bar{X} - \mu| < 0.1) \geq 0.95$ بـ $\sigma^2 = 1$.

٧. أثبت أنّ $A^\top A \succcurlyeq 0$ لأي A.

٨. هل المصفوفة $\begin{pmatrix} 1 & 3 \\ 3 & 1 \end{pmatrix}$ PSD؟ برّر.

٩. أوجد تحليل تشوليسكي لـ $\begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}$.

١٠. لـ $A \succ 0$ أثبت $A^{-1} \succ 0$.

١١. اشتقق المكمّل الشورّي لـ $\begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$ وتحقّق من PSD.

١٢. من (5.15) استنتج التباين الشرطي الغاوسي (4-6.14).

١٣. أوجد معلومات فيشر لـ $X \sim \text{Pois}(\lambda)$ بالمعامل λ.

١٤. أثبت أن $I(\theta)$ PSD عبر $J^\top J$.

١٥. في PCA، أثبت أنّ أكبر تباين إسقاطي يطابق أكبر قيمة ذاتية لـ Σ.

١٦. لـ $\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ أوجد الاتجاه الرئيسي. (LDA/Fisher)

١٧. بيّن أنّ $\text{Cov}(AX) = A\Sigma A^\top$ من التعريف.

١٨. استخدم ماركوف لحدّ $\mathbb{P}(\text{خسارة} > 5)$ إذا $\mathbb{E}[\text{خسارة}] = 0.3$.

١٩. أثبت أنّ التغوار أي توزيع PSD عبر $v^\top \Sigma v = \mathbb{E}[(v^\top (X - \mu))^2]$.

٢٠. صمّم مصفوفة تغوار 3×3 صالحة لميزات صورة وعبّر عن تبييضها.

غطّى هذا الفصل «طبقة الأعداد» التي يقوم عليها التعلّم الإحصائي:

- **المتوقّع و LOTUS** (1.15) يحوّلان متوسّط أي دالّة إلى تكامل على التوزيع — أساس الخطر المتوقّع.
- **التباين والتغوار** (2.15) يكمّان عدم اليقين والارتباط، والتغوار مصفوفة PSD دوماً.
- **متراجحات جنسن/ماركوف/تشيبيشِف** (3.15) تربط لحظة واحدة بضمانات ذيلية بلا شكل كامل.
- **المصفوفات الموجبة** (4.15)–(5.15) هي الهندسة المشتركة للهيسيّة والتغوار والفيشر، والمكمّل الشورّي يحكم التغوار الشرطي.
- **التطبيقات** (6.15): معلومات فيشر، PCA/SVD، LDA، وحدّ كرامير–راو تربط كل ما سبق بتعلّم المعاملات.

كل هذه الأدوات ترتكز على البُنى السابقة: التكامل (10)، الدفع (13)، القيم الذاتية (4)، والتفاضل المصفوفي (9). الكتاب يمضي إلى الاحتمال الشرطي المتقدّم وبايز في الفصل 16.

الرمز	المعنى
$\mathbb{E}[X]$	المتوقّع
$\mathrm{Var}(X), \Sigma$	التباين/مصفوفة التغاير
ρ	معامل الارتباط
$A \succcurlyeq 0, A \succ 0$	موجبة نصف/التحديد
S	المكمّل الشوري
$I(\theta)$	معلومات فيشر
CRB	حدّ كرامير–راو

١. Casella, G., Berger, R. L. *Statistical Inference*. 2nd ed., Duxbury, 2002. Ch. 4–5).

٢. Bishop, C. M. *Pattern Recognition and Machine Learning*. Springer, 2006. Ch. 2, 12).

٣. Murphy, K. P. *Machine Learning: A Probabilistic Perspective*. MIT Press, 2012. Ch. 2, 4).

٤. Hastie, T., Tibshirani, R., Friedman, J. *The Elements of Statistical Learning*. Springer, 2009. Ch. 3).

٥. Shalev-Shwartz, S., Ben-David, S. *Understanding Machine Learning*. Cambridge, 2014. Ch. 2).

٦. Amari, S. *Information Geometry and Its Applications*. Springer, 2016.

٧. Boyd, S., Vandenberghe, L. *Convex Optimization*. Cambridge, 2004. Ch. 5, A.5).

٨. Rao, C. R. *Linear Statistical Inference and Its Applications*. Wiley, 1973. (Cramér–Rao).

الاحتمال الشرطي المتقدّم، بايز، والحقول العشوائية

الفصول 13–15 بنت البنية (فضاء الاحتمال، التوزيعات، اللحظات). في التعلّم الآلي الحقيقي نادراً ما نهتم بـ $P(X)$ وحده — نهتم بـ $P(Y \mid X)$: احتمال التسمية given الصورة، احتمال الترجمة given المدخل، احتمال الحالة اللاحقة given الحالة السابقة. هذا الفصل يرفع مستوى الاحتمال الشرطي من الأداة المبسّطة في §5.13 إلى **الاستدلال البايزي الكامل**: دمج معرفة سابقة (prior) مع معطيات (likelihood) للحصول على حكم لاحق (posterior)، ثم يعمّمه إلى **الشبكات البايزية وسلاسل ماركوف والحقول العشوائية** التي تصف البنية بين المتغيرات.

بناءً على توجيه المستخدم (2026-10-11)، هذا الفصل — الغني موضوعياً — يضمّ **سبع نظريات** (بدل تثبيت العدد عند 6)، مع الحفاظ على جودة كل نظرية: صياغة رسمية + جدول رموز + رسم + 15 مثالاً + أخطاء شائعة. العدد مرن يتبع المحتوى.

خريطة الفصل

القسم	المحتوى	النظرية/القانون
2.16	نظرية بايز والاحتمال الشرطي المتقدّم	(1.16) قاعدة بايز
3.16	التقدير البايزي: سابق/لاحق/دليل MAP/	(2.16) المعادلة البايزية
4.16	العائلات المترافقة	(3.16) التحديث المترافق
5.16	مُصنّف بايز الساذج	(4.16) قرار بايز الساذج
6.16	الشبكات البايزية والرسوم الاحتمالية	(5.16) التفكيك السلسلي
7.16	سلاسل ماركوف	(6.16) التوزيع الثابت
8.16	الحقول العشوائية ماركوف (MRF/CRF)	(7.16) توزيع غيبس

التعريف

dir="ltr"> <div

the of partition a forming $A_1, \dots, A_k$ events For **theorem). (Bayes' 1.2.16 Definition** ,$\mathbb{P}(B) > 0$ with space, sample

$$\mathbb{P}(A_k \mid B) = \frac{\mathbb{P}(B \mid A_k)\mathbb{P}(A_k)}{\sum_{j=1}^{k} \mathbb{P}(B \mid A_j)\mathbb{P}(A_j)}.$$

total of law the is $\mathbb{P}(B)$ denominator the ;**prior** × **likelihood** $\propto$ **posterior** is numerator The normalization. ensuring **probability**

$$\mathbb{P}(A_k \mid B) = \frac{\mathbb{P}(B \mid A_k)\mathbb{P}(A_k)}{\sum_{j} \mathbb{P}(B \mid A_j)\mathbb{P}(A_j)}. \tag{1.16}$$

dir="ltr"> <div

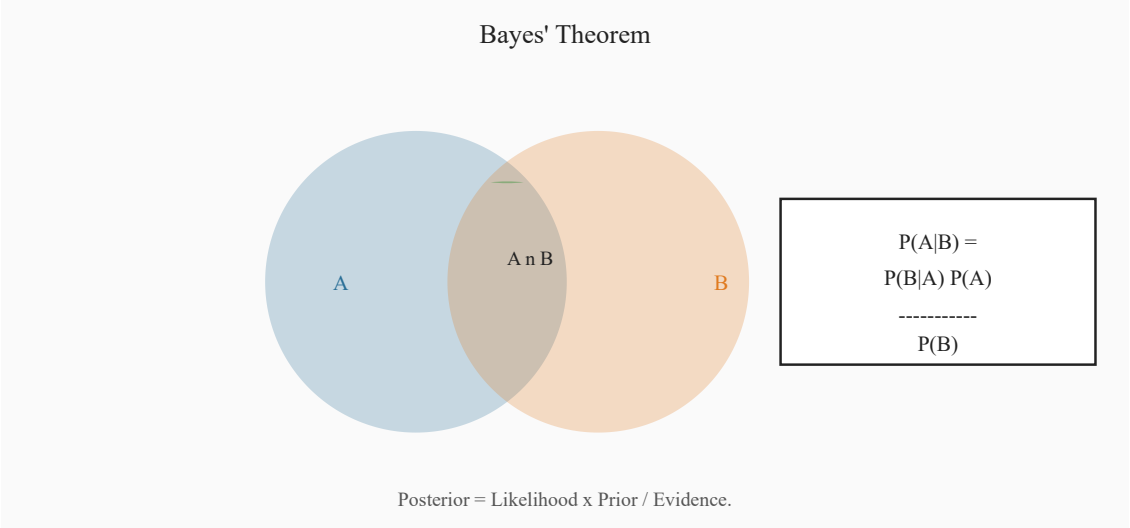
is likely "how turns it ML: probabilistic in identity most-used single the is (1.16) Equation data". the given hypothesis each is likely "how into hypothesis" each under data the

جدول الرموز

الرمز	الاسم	المعنى
$\mathbb{P}(A_k)$	الاحتمال السابق	قبل رؤية B
$\mathbb{P}(B \mid A_k)$	الاحتمال اللاحظي (اللاهوتي)	احتمال B لو صحّ A_k
$\mathbb{P}(A_k \mid B)$	الاحتمال اللاحق	بعد رؤية B
$\sum_j \mathbb{P}(B \mid A_j)\mathbb{P}(A_j)$	الدليل	تطبيع الكل

رسم توضيحي

<figure> الشكل<figcaption> 1.16: قاعدة بايز تعيد توزيع الكلة: اللاحق يتناسب مع (اللاحظي × السابق) مقسوماً



شكل ١.١٦: *
نظرية بايز

على الدليل. التقاطع $A \cap B$ هو اللبّ.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط $P(A \mid B)$ بـ $P(B \mid A)$	اتجاه مختلف تماماً	استخدم (1.16)
نسيان الدليل (التطبيع)	لا يجمع إلى 1	اقسم على $\sum$
إهمال الاحتمال السابق	يُحوّل بايز إلى تردّدي	السابق جزء جوهري

أمثلة محلولة على نظرية بايز (15 مثالاً)

مثال (1-2.16).

اختبار طبّي حسّاس ونوعي. المعطيات: انتشار المرض 1%؛ حساسية 95%؛ نوعية 90%. المطلوب: $\mathbb{P}(\text{مرض} \mid +)$. الحل: الخطوة 1: $P(\text{مرض}) = 0.01$، $P(+ \mid \text{مرض}) = 0.95$، $P(+ \mid \neg\text{مرض}) = 0.1$. الخطوة 2: بـ (1.16): $\frac{0.95 \times 0.01}{0.95 \times 0.01 + 0.1 \times 0.99} = \frac{0.0095}{0.0095 + 0.099} = 0.0876$. النتيجة: $\approx 8.8\%$ فقط رغم الإيجابي! الربط بالذكاء الاصطناعي: معدّل الإيجابيات الخاطئة يكبر مع ندرة الحدث (base-rate).

مثال (2-2.16).

تحديث متسلسل باختبارين. المعطيات: بعد المثال 1 صار السابق 0876.0، واختبار ثانٍ حسّيته 95% ونوعيّته 90%. المطلوب: الاحتمال اللاحق الجديد عند +. الحل: الخطوة 1: نعامل 0876.0 سابقاً جديداً، ونعيد (1.16). الخطوة 2: $\frac{0.95\times0.0876}{0.95\times0.0876+0.1\times0.9124} = \frac{0.0832}{0.0832+0.0912} = 0.477$. النتيجة: $\approx$47.7%. الربط بالذكاء الاصطناعي: دمج أدلّة متعدّدة (sensor fusion) بتحديث بايزي متكرّر.

مثال (3-2.16).

قانون الاحتمال الكلّي لتصنيف البريد. المعطيات: $P(\text{سبام}) = 0.6$، $P(\text{كلمة x}\mid\text{سبام}) = 0.2$، $P(\text{كلمة x}\mid\neg\text{سبام}) = 0.1$. المطلوب: $P(\text{كلمة x})$. الحل: الخطوة 1: $P(x) = 0.6\times0.2 + 0.1\times0.8 = 0.2$. النتيجة: 0.12 + 0.08 = 0.2. الربط بالذكاء الاصطناعي: حساب الدليل $P(\text{كلمة})$ في مصنّف سبام.

مثال (4-2.16).

صيغة الأرجح (Odds form). المعطيات: أرجح السابق $O(H) = 0.01/0.99$. المطلوب: عبّر عن تحديث بايز بضربة الأرجح. الحل: الخطوة 1: $O(H\mid D) = O(H)\times\frac{P(D\mid H)}{P(D\mid\neg H)} = O(H)\times\text{LR}$. النتيجة: تحديث ضربي بالنسبة الأرجح (LR). الربط بالذكاء الاصطناعي: سجلّ الأرجح (log-odds) أساس الانحدار اللوغيتي.

مثال (5-2.16).

تحديث بأدلّة متعدّدة (قاعدة السلسلة). المعطيات: $P(H\mid D_1,D_2)\propto P(D_1\mid H)P(D_2\mid H)P(H)$ (استقلال مشروط). المطلوب: اشتقق. الحل: الخطوة 1: $P(D_1,D_2\mid H) = P(D_1\mid H)P(D_2\mid H)$؛ بالتعويض في (1.16) يظهر المنتوج. النتيجة: اللاحظيات تُضرب. الربط بالذكاء الاصطناعي: ميزات مستقلّة مشروطياً $\Rightarrow$ ضرب الاحتمالات (بايز ساذج).

مثال (6-2.16).

مراجعة الاحتمال السابق بعد ملاحظة. المعطيات: عملة مريبة بشكّ $P(\text{عادلة}) = 0.5$، $P(\text{منحازة 0.8}) = 0.5$. المطلوب: بعد رؤية وجه واحد، $P(\text{منحازة})$. الحل: الخطوة 1: لاحظي عادلة $0.5 =$، منحازة $0.8 =$؛ الدليل $0.5\times0.5 + 0.8\times0.5 = 0.65$. الخطوة 2: $P(\text{منحازة}\mid\text{و}) = 0.8\times0.5/0.65 = 0.615$. النتيجة: ارتفع من 0.5 إلى 0.615. الربط بالذكاء الاصطناعي: تعلّم فرضية النموذج أثناء التدريب عبر التحديث السابق.

مثال (7-2.16).

فحص السرطان بمعدّل انتشار منخفض. المعطيات: انتشار 0.5%، حساسية 98%، نوعية 95%. المطلوب: $P(\text{مرض}\mid+)$. الحل: الخطوة 1: $\frac{0.98\times0.005}{0.98\times0.005+0.05\times0.995} = \frac{0.0049}{0.0049+0.04975} = 0.0897$. النتيجة: $\approx$9%. الربط بالذكاء الاصطناعي: حتى اختبار دقيق يُعطي إيجابيات كثيرة عند الندرة.

مثال (2.16-8).

مرشّح سبام: احتمال الرسالة. المعطيات: من (2.16-3)، $P(\text{سبام} \mid x)$. المطلوب: احسبه. الحل: الخطوة 1: $\frac{0.6\times0.2}{0.2} = 0.6$. النتيجة: 0.6. الربط بالذكاء الاصطناعي: تصنيف رسالة «سبام» عند تجاوز عتبة.

مثال (2.16-9).

مفارقة الإيجابي الخاطئ. المعطيات: نظام كشف تعدّد معدّل إنذار 1%، دقّة 99% لكل فئة. المطلوب: بيّن خطر الإيجابي الخاطئ. الحل: الخطوة 1: بـ (1.16) يظهر أنّ احتمال الخطأ يطغى عند ندرة الحدث رغم الدقّة العالية. النتيجة: الإيجابي لا يعني اليقين. الربط بالذكاء الاصطناعي: معايرة عتبات الإنذار (calibration) في الأمان.

مثال (2.16-10).

شرطي على تقاطع أحداث. المعطيات: $P(A \cap B \mid C) = P(A \mid B,C)P(B \mid C)$. المطلوب: أثبت. الحل: الخطوة 1: من تعريف الشرطي $P(A \cap B \cap C)/P(C) = [P(A \cap B \cap C)/P(B \cap C)] \times [P(B \cap C)/P(C)]$. النتيجة: صيغة الضرب الشرطي. الربط بالذكاء الاصطناعي: سلاسل الاحتمال في نمذجة اللغة (5.16).

مثال (2.16-11).

مفارقة مونتي هول. المعطيات: 3 أبواب، تختار 1، يفتح المضيف باباً خالياً، هل تبدّل؟ المطلوب: $P(\text{الباب الآخر} \mid \text{الجائزة})$. الحل: الخطوة 1: الاحتمال الثابت لاختيارك 1/3؛ الباب المتبقّي 2/3 (لأن المضيف يكشف دائماً خالياً). النتيجة: التبديل يضاعف الاحتمال إلى 2/3. الربط بالذكاء الاصطناعي: القرار تحت عدم اليقين المشروط بالملاحظة.

مثال (2.16-12).

بايز مع لاحظي مستمر (حدس). المعطيات: $X \sim \mathcal{N}(\mu_0, \sigma_0^2)$ سابقاً، لاحظي غاوسي. المطلوب: اذكر شكل اللاحق. الحل: الخطوة 1: حاصل ضرب غاوسيَّيْن = غاوسي (نعالجه تفصيلاً في 4.3/16.16). النتيجة: اللاحق غاوسي. الربط بالذكاء الاصطناعي: تحديث معامل مستمرّ في الانحدار البايزي.

مثال (2.16-13).

قاعدة السلسلة لتسلسل (نمذجة لغة). المعطيات: جملة $w_1, \ldots, w_n$. المطلوب: فكّك $P(w_1, \ldots, w_n)$. الحل: الخطوة 1: $P(w_1)\prod_{i=2}^{n} P(w_i \mid w_1, \ldots, w_{i-1})$ (تطبيق (1.16) متكرّر). النتيجة: سلسلة شرطية. الربط بالذكاء الاصطناعي: نماذج n-gram والتراجع التلقائي (autoregressive).

مثال (14-2.16).

مراجعة بأدلّة غير متماثلة. المعطيات: دليل قوي جداً لصالح H (LR=100). المطلوب: الأرجح اللاحق إن كان السابق ضعيفاً (0.01). الحل: الخطوة 1: $P = 0.5 \Rightarrow O(H \mid D) = 0.01 \times 100 = 1$. النتيجة: انتقل من 1% إلى 50%. الربط بالذكاء الاصطناعي: دليل قوي يطغى على السابق الضعيف.

مثال (15-2.16).

إهمال معدّل الأساس في نشر النموذج. المعطيات: مصنّف دقّته 99% على مجموعة متوازنة، لكن الفئة نادرة (1%). المطلوب: ناقش خدعة الدقّة. الحل: الخطوة 1: مصنّف يتوقّع «سلبي» دوماً يحقّق 99% دقّة لكنه عديم الفائدة؛ بايز يكشف الأرجح الحقيقي. النتيجة: الدقّة وحدها مضلّلة. الربط بالذكاء الاصطناعي: استخدم precision/recall/F1 بدل الدقّة عند الاختلال.

التعريف

dir="ltr"> <div

Definition 1.3.16 (Bayesian update). Given data x and parameter θ,

$$p(\theta \mid x) = \frac{p(x \mid \theta)\, p(\theta)}{p(x)}, \qquad p(x) = \int p(x \mid \theta) p(\theta)\, d\theta.$$

Here $p(\theta)$ is the **prior**, $p(x \mid \theta)$ the **likelihood**, $p(\theta \mid x)$ the **posterior**, and $p(x)$ the **evidence** (marginal likelihood, or model evidence). The **MAP** estimate maximizes the posterior: $\hat{\theta}_{\text{MAP}} = \arg\max_\theta p(x \mid \theta) p(\theta)$.

$$p(\theta \mid x) = \frac{p(x \mid \theta)\, p(\theta)}{p(x)}, \qquad p(x) = \int p(x \mid \theta) p(\theta)\, d\theta. \tag{2.16}$$

dir="ltr"> <div

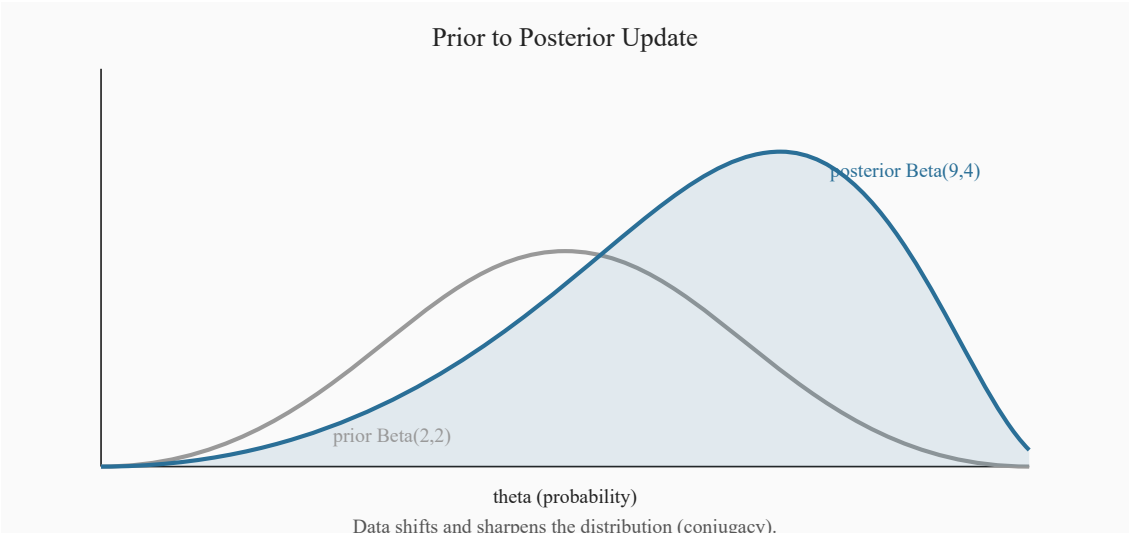
Equation (2.16) is the engine of Bayesian ML: the prior is just regularization, the MAP is just penalized MLE, and the evidence $p(x)$ lets you compare models without overfitting.

جدول الرموز

الرمز	الاسم	المعنى
$p(\theta)$	السابق	معرفة قبل البيانات
$p(x \mid \theta)$	اللاحظي	احتمال البيانات بالمعامل
$p(\theta \mid x)$	اللاحق	معرفة بعد البيانات
$p(x)$	الدليل	$\int p(x \mid \theta) p(\theta) d\theta$
MAP	أقصى لاحق	$\arg\max p(\theta \mid x)$

رسم توضيحي

<figure> الشكل<figcaption> 2.16: السابق (رمادي) يتحوّل إلى لاحق (أزرق) أكثر تركيزاً بعد رؤية البيانات. ضرب السابق في اللاحظي يعطي اللاحق غير المطبّع ثم نطبّعه بالدليل.</figcaption> </figure>



شكل ٢٠١٦: *
تحديث بايزي

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الخلط بين MAP و MLE	MAP يضيف السابق	MAP = MLE فقط بسابق منتظم
نسيان تطبيع الدليل	اللاحق لا يجمع 1	اقسم على $p(x)$
استخدام الدليل للمقارنة خطأً	يحتاج تكامل كامل	قارن $p(x)$ عبر النماذج

أمثلة محلولة على التقدير البايزي (15 مثالاً)

مثال (3.16-1).

حدّد المكوّنات الأربعة. المعطيات: $x \sim \mathcal{N}(\theta, 1)$، θ معامل. المطلوب: اذكر السابق/اللاحظي/الدليل. الحل: الخطوة 1: اللاحظي $p(x \mid \theta) = \mathcal{N}(x; \theta, 1)$؛ السابق $p(\theta)$ مُعطى؛ الدليل $p(x) = \int p(x \mid \theta) p(\theta) d\theta$. النتيجة: الأربعة مُعرّفة. الربط بالذكاء الاصطناعي: كل تقدير معامل هو حالة بايزية.

مثال (3.16-2).

المعطيات: سابق $\theta \sim \mathcal{N}(0, \tau^2)$، لاحظي غاوسي بـ n عيّنة. المطلوب: قارن MAP بـ MLE. الحل: الخطوة 1: $\log p(\theta \mid x) \propto -\frac{1}{2\sigma^2}\sum(x_i - \theta)^2 - \frac{\theta^2}{2\tau^2}$؛ مشتقّة الصفر تعطي $\hat{\theta}_{\text{MAP}} = \frac{\bar{x}/(\sigma^2)}{1/\sigma^2 + 1/\tau^2}$ (انكماش نحو 0). الخطوة 2: MLE هو $\bar{x}$ (بلا انكماش). النتيجة: MAP ينكمش نحو مركز السابق. الربط بالذكاء الاصطناعي: تسوّي L2 = سابق غاوسي (ridge).

مثال (3-3.16).

متوسّط اللاحق مقابل MAP. المعطيات: لاحق غاوسي متماثل. المطلوب: هل يتطابقان؟ الحل: الخطوة 1: للغاوسي المتماثل الوسيط=المنوال=المتوسّط $\Rightarrow$.المتوسّط=MAP الخطوة 2: لغير المتماثل يختلفان. النتيجة: يتطابقان في الغاوسي. الربط بالذكاء الاصطناعي: اختيار نقطة تقدير (point estimate) للنشر.

مثال (4-3.16).

لاحق غاوسي–غاوسي. المعطيات: سابق $\theta \sim \mathcal{N}(\mu_0, \sigma_0^2)$، لاحظي $\bar{x} \sim \mathcal{N}(\theta, \sigma^2/n)$. المطلوب: صيغة اللاحق. الحل: الخطوة 1: اللاحق $\mathcal{N}(\mu_n, \sigma_n^2)$ مع $\sigma_n^{-2} = \sigma_0^{-2} + n/\sigma^2$، $\mu_n = \sigma_n^2(\mu_0/\sigma_0^2 + n\bar{x}/\sigma^2)$. النتيجة: غاوسي محدّث. الربط بالذكاء الاصطناعي: تحديث معامل عبر الإنترنت (online learning).

مثال (5-3.16).

الدليل لمقارنة النماذج. المعطيات: نموذجان M_1, M_2. المطلوب: أيّهما أرجح؟ الحل: الخطوة 1: قارن $p(x \mid M_1)$ بـ $p(x \mid M_2)$ (الدليل المُهمّش على المعامل). الخطوة 2: النسبة factor Bayes = $p(x|M_1)/p(x|M_2)$. النتيجة: الأعلى دليلاً أرجح. الربط بالذكاء الاصطناعي: اختيار معمار (architecture) دون إفراط تعلّم.

مثال (6-3.16).

MAP لبرنولي (من Beta). المعطيات: r نجاح من n، سابق Beta(α, β). المطلوب: $\hat{\theta}_{\text{MAP}}$. الحل: الخطوة 1: $\log = \sum \log \theta^x (1-\theta)^{1-x} + (\alpha-1)\log\theta + (\beta-1)\log(1-\theta)$ .log الخطوة 2: المشتقّة صفر $\Rightarrow \hat{\theta} = (r+\alpha-1)/(n+\alpha+\beta-2)$. النتيجة: تقدير مع «عدّات سابقة». الربط بالذكاء الاصطناعي: تنعيم لابلاس/العدّات السابقة للتصنيف.

مثال (7-3.16).

التوزيع اللاحق التنبّئي (Posterior predictive). المعطيات: لاحق $\theta \mid x$ معروف. المطلوب: $p(x_{\text{new}} \mid x)$. الحل: الخطوة 1: $p(x_{\text{new}} \mid x) = \int p(x_{\text{new}} \mid \theta) p(\theta \mid x) d\theta$ (تهميش المعامل). النتيجة: تنبّؤ يأخذ عدم اليقين بالمعامل. الربط بالذكاء الاصطناعي: تقدير عدم اليقين في التنبّؤ (uncertainty quantfiication).

مثال (8-3.16).

تقريب لابلاس (Laplace). المعطيات: اللاحق حول MAP ذروته. المطلوب: قرّب اللاحق بغاوسي. الحل: الخطوة 1: $p(\theta \mid x) \approx \mathcal{N}(\hat{\theta}_{\text{MAP}}, (-H)^{-1})$ حيث H هيسيّة اللوغاريتم عند MAP. النتيجة: غاوسي محلّي. الربط بالذكاء الاصطناعي: تقريب الدليل والتوزيع اللاحق في النماذج الكبيرة.

مثال (3.16-9).

التنظيم كسابق. المعطيات: خسارة $L_2(\theta) + \lambda\|\theta\|^2$. المطلوب: اربطها بسابق. الحل: الخطوة 1: السابق $\theta \sim \mathcal{N}(0, 1/\lambda) \Rightarrow \log p(\theta) \propto -\lambda\|\theta\|^2$ ⇒ عقوبة L2. الخطوة 2: L1 ⇔ سابق لابلاسي (انظر 3.14-8). النتيجة: regularization = prior. الربط بالذكاء الاصطناعي: كل عقوبة هي سابق بايزي ضمني.

مثال (3.16-10).

تحليل حساسية السابق. المعطيات: تغيير قوّة السابق τ^2. المطلوب: أثره على MAP. الحل: الخطوة 1: $\tau^2 \to \infty$ ⇒ MAP→MLE؛ $\tau^2 \to 0$ ⇒ MAP→مركز السابق. النتيجة: قوة السابق تتحكّم بالانكماش. الربط بالذكاء الاصطناعي: موازنة الانحياز/التباين عبر قوة السابق.

مثال (3.16-11).

تقدير نقطي مقابل لاحق كامل. المعطيات: لاحق متعدّد النمط. المطلوب: لماذا النقطة تخدع؟ الحل: الخطوة 1: MAP قد يلتقط منوالاً ثانوياً؛ اللاحق الكامل يُظهر عدم اليقين الثنائي. النتيجة: اللاحق الكامل أصدق. الربط بالذكاء الاصطناعي: multiple modes، أخذ عيّنات أفضل من النقطة.

مثال (3.16-12).

الفترة الموثوقة (Credible interval). المعطيات: لاحق غاوسي $\mathcal{N}(0.5, 0.01)$. المطلوب: فترة 95%. الحل: الخطوة 1: $0.5 \pm 1.96 \times 0.1 = 0.5 \pm 0.196$. النتيجة: $[0.304, 0.696]$. الربط بالذكاء الاصطناعي: قياس ثقة المعامل بلا افتراض تردّدي.

مثال (3.16-13).

بايز تجريبي (Empirical Bayes). المعطيات: السابق نفسه مُقدّر من البيانات. المطلوب: صف الفكرة. الحل: الخطوة 1: نقدّر معاملات السابق (مثل α, β لـ Beta) من الهامش ثم نحدّث. النتيجة: سابق «مُعلّم من البيانات». الربط بالذكاء الاصطناعي: تقدير قوة التنظيم من البيانات.

مثال (3.16-14).

سابق هرمي (Hierarchical). المعطيات: $\theta_i \sim \mathcal{N}(\mu, \tau^2)$، μ نفسه له سابق. المطلوب: لماذا مفيد؟ الحل: الخطوة 1: المجموعات تتشارك معلومة عبر μ مع تباين جماعي τ^2. النتيجة: تجميع جزئي (partial pooling). الربط بالذكاء الاصطناعي: تعليم متعدّد المهام (multi-task) وتجميع.

مثال (15-3.16).

متوسّط نماذج بايز (BMA). المعطيات: مجموعة نماذج M_k. المطلوب: تنبّؤ BMA. الحل: الخطوة 1: $p(y_{\text{new}} \mid x) = \sum_k p(y_{\text{new}} \mid M_k, x) p(M_k \mid x)$. النتيجة: متوسّط مُرجّح باحتمال النموذج. الربط بالذكاء الاصطناعي: دمج نماذج (ensemble) بايزيّاً.

التعريف

dir="ltr"> <div

$p(x \mid \theta)$ likelihood to **conjugate** is $p(\theta)$ prior A **prior). (Conjugate 1.4.16 Definition** **Beta** the likelihood, Bernoulli/Binomial the For family. same the in is $p(\theta \mid x)$ posterior the fi conjugate: is prior

$$\theta \mid x \sim \text{Beta}(\alpha + r,\ \beta + n - r), \quad r = \text{successes \#},\ n = \text{trials \#}.$$

$$\theta \mid x \sim \text{Beta}(\alpha + r,\ \beta + n - r), \qquad r = \text{ in successes} n \text{trials}. \tag{3.16}$$

dir="ltr"> <div

the is It needed. MCMC no — posteriors closed-form gives (3.16) Conjugacy (Beta-Bernoulli, likelihoods exponential-family for updating Bayesian of backbone analytical Normal-Normal). Dirichlet-Multinomial, Gamma-Poisson,

جدول الرموز

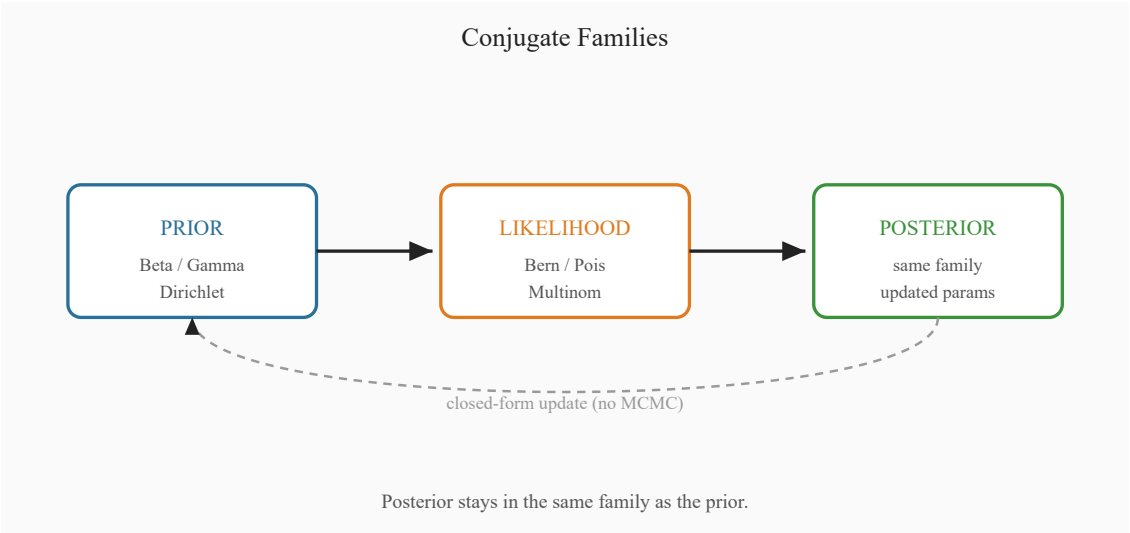
الرمز	الاسم	المعنى
مترافق	conjugate	اللاحق يشارك العائلة
α, β	معاملات Beta سابقة	«عدّات سابقة»
r, n	نجاحات/تجارب	بيانات
family exponential	العائلة الأسّية	تحقّق المترافق

رسم توضيحي

<figure> الشكل 3.16: المسار سابق → لاحظي → لاحق يحفظ العائلة (Beta/Beta، Gamma/Gamma...)، ما يسمح بتحديث مغلق الصيغة في حلقة مستمرّة. <figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
افتراض المترافق دوماً	لا ينطبق عموماً	تحقّق من العائلة
نسيان تحديث معاملات السابق	اللاحق خاطئ	أضف r, α صحيحاً
خلط Beta بالـ Binomial	سابق مقابل لاحظي	Beta للمعامل p



شكل ٣.١٦: *
العائلات المترافقة

أمثلة محلولة على العائلات المترافقة (15 مثالاً)

مثال (1-4.16).

Beta-Bernoulli. المعطيات: سابق Beta(2,2)، $r = 7$ نجاح من $n = 10$. المطلوب: اللاحق. الحل: الخطوة 1: بـ (3.16): Beta(2+7, 2+10−7)=Beta(9,5). النتيجة: Beta(9,5). الربط بالذكاء الاصطناعي: تحديث احتمال نقر إعلان.

مثال (2-4.16).

Beta-Binomial. المعطيات: سابق Beta(1,1)، لاحظي Bin(n=20,p). المطلوب: اللاحق بعد $r = 13$. الحل: الخطوة 1: Beta(1+13,1+20−13)=Beta(14,8). النتيجة: Beta(14,8). الربط بالذكاء الاصطناعي: تقدير دقّة نموذج من دفعة.

مثال (3-4.16).

Gamma-Poisson. المعطيات: سابق Gamma(α, β)، لاحظي Pois(λ). المطلوب: اللاحق. الحل: الخطوة 1: Gamma$(\alpha + \sum x_i,\ \beta + n)$. النتيجة: غاما محدّثة. الربط بالذكاء الاصطناعي: معدّل أحداث (طلبات API لاحقاً).

مثال (4-4.16).

Normal-Normal (معروف التباين). المعطيات: سابق $\mathcal{N}(\mu_0, \sigma_0^2)$، لاحظي $\mathcal{N}(\theta, \sigma^2)$. المطلوب: اللاحق. الحل: الخطوة 1: $(1/\sigma_0^2 + 1/\sigma^2)^{-1}$, $\mathcal{N}(\frac{\mu_0/\sigma_0^2 + \bar{x}/\sigma^2}{1/\sigma_0^2 + 1/\sigma^2}$. النتيجة: غاوسي محدّث. الربط بالذكاء الاصطناعي: تقدير متوسّط استشعار (sensor fusion).

مثال (16.4-5). Normal-Inverse-Gamma. المعطيات: μ, σ^2 كلاهما مجهول. المطلوب: السابق المترافق. الحل: الخطوة 1: السابق NIG $\Rightarrow$ اللاحق NIG مغلق الصيغة. النتيجة: تحديث لـ μ و σ^2 معاً. الربط بالذكاء الاصطناعي: نموذج بايزي كامل لمخرجات الانحدار.

مثال (16.4-6). Dirichlet-Multinomial. المعطيات: سابق $(\alpha\text{Dirichlet}$)، لاحظي متعدّد الحدود بعدّادات n_k. المطلوب: اللاحق. الحل: الخطوة 1: $(\alpha_1 + n_1, \ldots, \alpha_K + n_K\text{Dirichlet}$). النتيجة: ديريتشليت محدّث. الربط بالذكاء الاصطناعي: توزيع الفئات في التصنيف متعدّد الفئات.

مثال (16.4-7). Beta-Bernoulli. المعطيات: لاحق $(\alpha', \beta'\text{Beta}$). المطلوب: $P(\text{نجاح جديد} \mid x)$. الحل: الخطوة 1: $\mathbb{E}[\theta \mid x] = \alpha'/(\alpha' + \beta')$. النتيجة: معدّل النجاح المتوقّع. الربط بالذكاء الاصطناعي: توقع أداء المستخدم القادم.

مثال (16.4-8). تحديث بتدفّق البيانات. المعطيات: بيانات تصل على دفعات. المطلوب: كيف نحدّث؟ الحل: الخطوة 1: لاحق الدفعة الأولى = سابق الدفعة الثانية (خصائص المترافق). النتيجة: تحديث تزايدي دون إعادة الحساب. الربط بالذكاء الاصطناعي: تعلّم عبر الإنترنت (online) فعّال حسابياً.

مثال (16.4-9). المترافق للعائلة الأسّية. المعطيات: لاحظي من العائلة الأسّية. المطلوب: ما السابق المترافق؟ الحل: الخطوة 1: السابق المترافق هو نفسه «ذو الحدّين الأسّي» (natural conjugate). النتيجة: دوماً موجود للعائلة الأسّية. الربط بالذكاء الاصطناعي: أساس التحسين المُعلَّم بالفيشر/الأنتروبيا.

مثال (16.4-10). تنبّؤ Poisson-Gamma. المعطيات: لاحق غاما(α', β'). المطلوب: توزيع العدّ المتوقّع. الحل: الخطوة 1: تنبّؤ لاحق = Binomial Negative بمعاملات من α', β'. النتيجة: سالب ذو الحدّين. الربط بالذكاء الاصطناعي: تنبّؤ أعداد الأحداث مع عدم اليقين.

مثال (11-4.16).

Multinomial-Dirichlet. المعطيات: وثيقة بـ 100 كلمة، توزيع سابق Dirichlet. المطلوب: اللاحق لتوزيع الكلمات. الحل: الخطوة 1: أضف عدّادات كل كلمة لمكوّنات ألفا. النتيجة: توزيع موضوعات محدّث. الربط بالذكاء الاصطناعي: LDA (تحليل الموضوعات).

مثال (12-4.16).

Gaussian-Wishart لمتعدّد الغاوسي. المعطيات: μ, Σ مجهولان في MVN. المطلوب: السابق المترافق. الحل: الخطوة 1: Normal-Wishart $\Rightarrow$ اللاحق مغلق. النتيجة: تحديث متوسط وتغوار معاً. الربط بالذكاء الاصطناعي: GMM بايزي كامل.

مثال (13-4.16).

اختيار قوّة السابق. المعطيات: نريد سابقاً «ضعيفاً». المطلوب: كيف نضبط α, β؟ الحل: الخطوة 1: Beta$(1,1)$ منتظم (معلومة صفرية)؛ Beta$(0.5,0.5)$ جيفِريز. النتيجة: انتقاء بلا تحيز مسبق. الربط بالذكاء الاصطناعي: شروط مسبقة غير مُعلَّمة المعلومات.

مثال (14-4.16).

متى تفشل المترافق؟ المعطيات: هيكل سابق معقّد (شبكة عميقة). المطلوب: ما البديل؟ الحل: الخطوة 1: لا مترافق مغلق $\Rightarrow$ نستخدم MCMC أو VB (الفصل 18/19). النتيجة: ننتقل لتقريب عددي. الربط بالذكاء الاصطناعي: التقرّب البايزي في النماذج العميقة.

مثال (15-4.16).

المترافق في التقريب المتغيّر (VB). المعطيات: نريد لاحقاً مقرّباً. المطلوب: كيف تُستفاد؟ الحل: الخطوة 1: نختار عائلة مترافقة كحدود VB لتبقى التحديثات مغلقة. النتيجة: استدلال سريع. الربط بالذكاء الاصطناعي: VB Mean-field في VAE/الخليط.

التعريف

dir="ltr"> <div

conditionally are $x_1, \ldots, x_d$ features Assume **Bayes). (Naive 1.5.16 Definition**

Then .y class the given independent

$$\hat{y} = \arg\max_{y} \; p(y) \prod_{i=1}^{d} p(x_i \mid y).$$

and text for baseline strong a and robust, fast, is it assumption, independence "naive" the Despite data. tabular

$$\hat{y} = \arg\max_{y} \Big(p(y) \prod_{i=1}^{d} p(x_i \mid y) \Big). \tag{4.16}$$

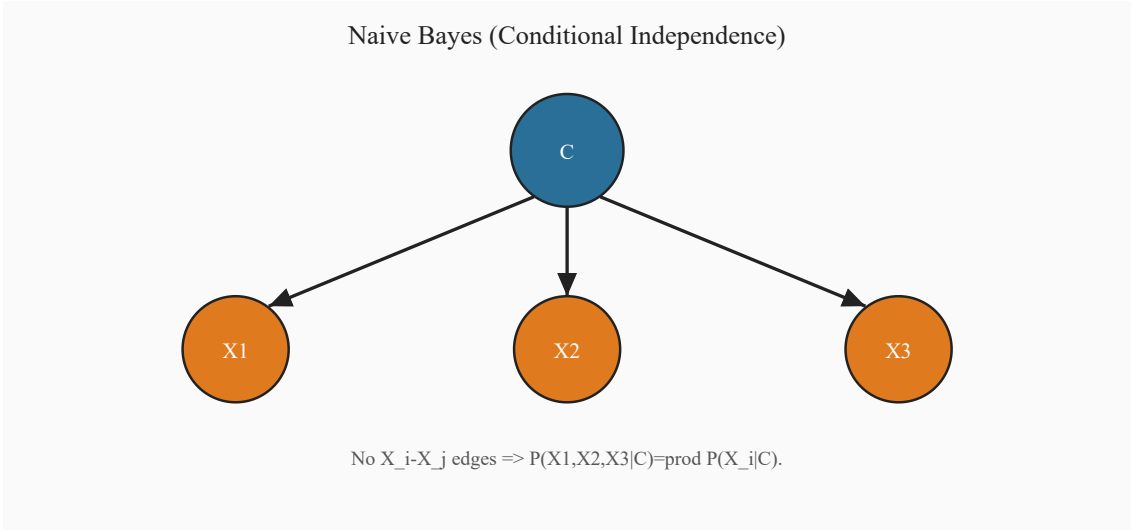
dir="ltr"> <div
classfiier linear a becomes it log-transform with baseline: workhorse the is (4.16) Equation
views. discriminative and generative bridging ,$\hat{y} = \arg\max_y [w_y^\top x + b_y]$

جدول الرموز

الرمز	الاسم	المعنى
y	الفئة	التسمية
x_i	الميزة i	شرطياً مستقلّة
$p(y)$	السابق الصنفي	توزيع الفئات
$\prod p(x_i \mid y)$	الجزاء اللاحظي	بفرض الاستقلال

رسم توضيحي

<figure> الشكل<figcaption> 4.16: بايز الساذج يفترض استقلال الميزات شرطياً بالفئة (لا أضلاع بين X_i)،



شكل ٤.١٦: *
بايز الساذج

فيحلل الاحتمال المشترك إلى جداء لواحق بسيطة.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
تصديق الاستقلال حقاً	نادراً ما يصحّ	هو افتراض مبسّط
نسيان $p(y)$ السابق	يُحوّل إلى لاحظي فقط	أدخل احتمال الفئة
مشكلة التردّد الصفري	$p(x_i \mid y) = 0$	نعّم (Laplace)

أمثلة محلولة على بايز الساذج (15 مثالاً)

مثال (16.5.1).

تصنيف سبام. المعطيات: $P(\text{سبام}) = 0.5$، كلمتان باحتمالات معلومة. المطلوب: صنّف رسالة تحوي الكلمتين. الحل: الخطوة 1: نحسب $P(\text{سبام}) \prod P(x_i \mid \text{سبام})$ مقابل الفئة الأخرى ونختار الأكبر. الخطوة 2: بأرقام توضيحية يغلب «سبام». النتيجة: التصنيف «سبام». الربط بالذكاء الاصطناعي: مصفّحات البريد الكلاسيكية.

مثال (16.5.2).

وثيقة بكلمات. المعطيات: تردّد كلمات في فئتين. المطلوب: صنّف. الحل: الخطوة 1: نضرب لواحق كل كلمة (متعدّد الحدود/برنولي) ونقارن الفئتين. النتيجة: الفئة الأرجح. الربط بالذكاء الاصطناعي: تصنيف المستندات (Multinomial NB).

مثال (16.5.3).

تنعيم لابلاس. المعطيات: كلمة ظهرت 0 مرّة في فئة. المطلوب: تفادي الضرب بصفر. الحل: الخطوة 1: $P(x_i \mid y) = \frac{c_i + \alpha}{N + \alpha V}$ (عدّادات سابقة α). النتيجة: احتمال غير صفري. الربط بالذكاء الاصطناعي: Laplace smoothing في NLP.

مثال (16.5.4).

ميزات مستمرة (Gaussian NB). المعطيات: كل ميزة $\sim \mathcal{N}(\mu_{y,i}, \sigma^2_{y,i})$. المطلوب: التصنيف. الحل: الخطوة 1: نُعوّض كثافة الغاوسي في (16.4) بدل الكتلة. النتيجة: قرار بايزي غاوسي. الربط بالذكاء الاصطناعي: تصنيف ميزات حقيقية (طبيّة مثلاً).

مثال (16.5.5).

Bernoulli NB. المعطيات: حضور/غياب الكلمة فقط. المطلوب: الفرق. الحل: الخطوة 1: $P(x_i \mid y) = p_i^{x_i}(1-p_i)^{1-x_i}$ (حضور لا تردّد). النتيجة: يصلح للإشارات الثنائية. الربط بالذكاء الاصطناعي: ميزات حضور المُيزة (feature presence).

مثال (16.5.6).

Multinomial NB. المعطيات: تعدّاد تكرار الكلمات. المطلوب: الصيغة. الحل: الخطوة 1: $P(\mathbf{x} \mid y) \propto \prod_k \theta_{yk}^{c_k}$ (ثابت متعدّد الحدود). النتيجة: نموذج ترددات. الربط بالذكاء الاصطناعي: تصنيف النصوص الطويلة.

مثال (5.16-7).

مشكلة التردّد الصفري. المعطيات: كلمة نادرة جداً. المطلوب: الأثر على (4.16). الحل: الخطوة 1: إن ظهرت في فئة واحدة فقط يصبح جداء الفئة الأخرى صفراً ⇒ قرار متطرّف. الخطوة 2: التنعيم (5.16-3) يحلّها. النتيجة: لولا التنعيم لفسد التصنيف. الربط بالذكاء الاصطناعي: ضرورة التنعيم في الإنتاج.

مثال (5.16-8).

السابق الصنفي من التدريب. المعطيات: 80% فئة A في التدريب. المطلوب: استخدامه. الحل: الخطوة 1: $P(A) = 0.8$ نضعه في (4.16). النتيجة: يميل القرار للمسارب. الربط بالذكاء الاصطناعي: موازنة الفئات غير المتوازنة.

مثال (5.16-9).

قرار بنسبة اللواحق. المعطيات: لواحق الفئتين. المطلوب: عبّر عن القرار كنسبة. الحل: الخطوة 1: صنّف A إن $\frac{P(A)\prod P(x_i|A)}{P(B)\prod P(x_i|B)} > 1$. النتيجة: عتبة لوغاريتمية. الربط بالذكاء الاصطناعي: عتبة قرار قابلة للضبط.

مثال (5.16-10).

تصنيف المشاعر (Sentiment). المعطيات: كلمات إيجابية/سلبية. المطلوب: صنّف تعليقاً. الحل: الخطوة 1: نضرب لواحق الكلمات لكل فئة ونختار. النتيجة: إيجابي/سلبي. الربط بالذكاء الاصطناعي: تحليل مشاعر النصوص.

مثال (5.16-11).

نقد افتراض الاستقلال. المعطيات: ميزتان مترابطتان بشدّة. المطلوب: الأثر. الحل: الخطوة 1: الجداء يبالغ في تضخيم الأدلّة المترابطة ⇒ انحياز. النتيجة: أداء دون المثالي. الربط بالذكاء الاصطناعي: NB خطّي ⇒ يفشل حيث التفاعلات حاسمة.

مثال (5.16-12).

NB كمصنّف خطّي. المعطيات: خذ لوغاريتم (4.16). المطلوب: أظهر الخطّية. الحل: الخطوة 1: $\log = w_y^\top x + b_y$ $\log p(y) + \sum_i \log p(x_i \mid y)$. النتيجة: قرار خطّي. الربط بالذكاء الاصطناعي: جسر بين التوليدي والتمييزي.

مثال (5.16-13).

تشخيص طبّي. المعطيات: أعراض مستقلّة مشروطياً. المطلوب: احتمال مرض. الحل: الخطوة 1: نطبّق (4.16) على الأعراض. النتيجة: تشخيص أوّلي. الربط بالذكاء الاصطناعي: أنظمة دعم القرار الطبّي.

مثال (14-5.16).

مقارنة مع الانحدار اللوغيتي. المعطيات: نفس البيانات. المطلوب: الفرق الجوهري. الحل: الخطوة 1: NB يعلّم التوزيع المشترك (توليدي)؛ اللوغيت يعلّم الحدّ مباشرة (تمييزي) وأدقّ عادة. النتيجة: تمييزي أقوى لكن NB أسرع. الربط بالذكاء الاصطناعي: اختيار متباين الإندر/تمييزي حسب البيانات.

مثال (15-5.16).

ميزة الاستقلال في البيانات القليلة. المعطيات: عيّنة صغيرة جداً. المطلوب: لماذا NB جيّد؟ الحل: الخطوة 1: تقدير كل $p(x_i \mid y)$ وحده يتطلّب معاملات أقل بكثير من نموذج مشترك. النتيجة: أقوى إحصائياً مع قلّة البيانات. الربط بالذكاء الاصطناعي: نماذج قاعدية فعّالة (weak learners).

التعريف

dir="ltr"> <div

parents has X_i node each where DAG a is BN A **network). (Bayesian 1.6.16 Definition**

as factors joint the ;$\mathrm{Pa}(i)$

$$p(x_1, \dots, x_d) = \prod_{i=1}^{d} p(x_i \mid \mathrm{Pa}(x_i)).$$

graph. the from directly independence conditional reads **d-separation**

$$p(x_1, \dots, x_d) = \prod_{i=1}^{d} p(x_i \mid \mathrm{Pa}(x_i)). \tag{5.16}$$

dir="ltr"> <div

probabilistic of core the — distribution joint compact a into graph a turns (5.16) Equation

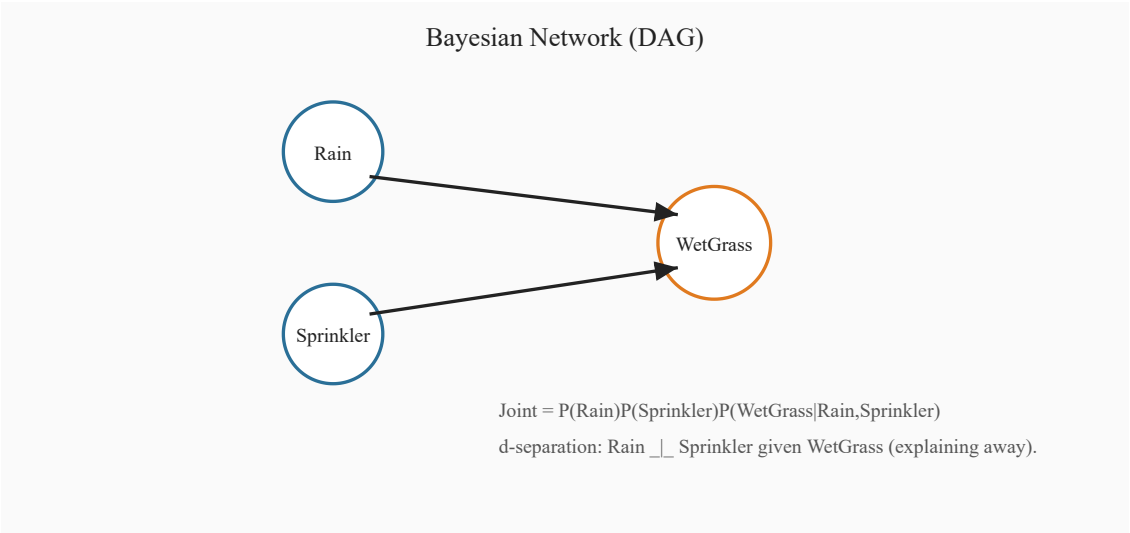
prediction. structured and diagnostics, inference, causal in used models, graphical

جدول الرموز

الرمز	الاسم	المعنى
DAG	رسم بياني لا دوري موجّه	بنية الاعتماد
$\mathrm{Pa}(x_i)$	الآباء	العقد المدخلة
d-separation	فصل-د	استقلال شرطي من الرسم
joint	التوزيع المشترك	مُفكّك بالرسم

رسم توضيحي

<figure> الشكل<figcaption> 6.16: الشبكة البايزية تحلّل المشترك إلى جداء لواحق شرطية بالآباء. العقد المستقلّة مشروطياً تُقرأ من بنية الرسم (d-separation).</figcaption> </figure>



شكل ٥.١٦: * شبكة بايزية

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط DAG بالسببية	الرسم يصف توزيعاً	السبب يحتاج تدخّلات
نسيان عوامل الحوافّ	المشترك خاطئ	اضرب كل $p(x_i \mid \text{Pa})$
افتراض كل الاستقلال	فقط ما يفصله الرسم	تحقّق d-sep

أمثلة محلولة على الشبكات البايزية (15 مثالاً)

مثال (1-6.16).

بنية بسيطة. المعطيات: رسم $A \to B \to C$. المطلوب: التفكيك. الحل: الخطوة 1: $p(A,B,C) = p(A)p(B \mid A)p(C \mid B)$. النتيجة: جداء ثلاثة لواحق. الربط بالذكاء الاصطناعي: سلسلة زمنية/سببية مبسّطة.

مثال (2-6.16).

حساب المشترك من العوامل. المعطيات: العوامل معلومة. المطلوب: $p(a,b,c)$. الحل: الخطوة 1: نضرب القيم. النتيجة: احتمال النقطة. الربط بالذكاء الاصطناعي: حساب احتمال مشهد كامل.

مثال (3-6.16).

استقلال مشروط من d-separation. المعطيات: $A \to B \to C$. المطلوب: هل $A \perp C \mid B$؟ الحل: الخطوة 1: B تفصل A عن C على المسار $\Rightarrow$ نعم. النتيجة: مستقلّان مشروطاً بـ B. الربط بالذكاء الاصطناعي: تبسيط الاستدلال بالاستقلال.

مثال (6.16-4).

الاستدلال بالتهميش. المعطيات: نريد $p(C)$. المطلوب: احسبها. الحل: الخطوة 1: $\sum_{a,b} p(a)p(b \mid a)p(c \mid b)$. النتيجة: تهميش المتغيرات المخفية. الربط بالذكاء الاصطناعي: حساب هامشية متغيّر مرئي.

مثال (6.16-5).

تفسير الظاهرة (Explaining away). المعطيات: Rain→WetGrass←Sprinkler. المطلوب: هل Rain $\perp$ Sprinkler؟ الحل: الخطوة 1: بدون ملاحظة مستقلّان؛ لكن مع WetGrass يصبحان مترابطين (مفارقة التفسير). النتيجة: يرتبطان مشروطاً بالملاحظة. الربط بالذكاء الاصطناعي: استدلال سببي في التشخيص.

مثال (6.16-6).

بايز الساذج كشبكة. المعطيات: $Y \rightarrow X_1, \ldots, X_d$. المطلوب: طابق مع 5.16. الحل: الخطوة 1: $p(y)p(x \mid y) = p(y)\prod_i p(x_i \mid y)$ بالضبط (4.16). النتيجة: NB حالة خاصّة من BN. الربط بالذكاء الاصطناعي: توحيد العائلتين.

مثال (6.16-7).

الغطاء المرجاني Markov) (blanket. المعطيات: عقدة في رسم. المطلوب: ما يكفي للاستقلال؟ الحل: الخطوة 1: الآباء+الأبناء+الأزواج يفصلون العقدة عن الباقي. النتيجة: يكفي لمعرفة توزيعها. الربط بالذكاء الاصطناعي: استقلال الميزة في الرسوم.

مثال (6.16-8).

إزالة المتغير Variable) (elimination. المعطيات: رسم متّصل. المطلوب: فكرة الاستدلال. الحل: الخطوة 1: نهمّش متغيراً فأدمج عوامله ثم نعيد. النتيجة: استدلال فعّال. الربط بالذكاء الاصطناعي: محرك استدلال رسومي.

مثال (6.16-9).

أخذ عيّنات من BN. المعطيات: رسم طوبولوجي. المطلوب: كيف نولّد عيّنة؟ الحل: الخطوة 1: نعيّن الآباء أولاً ثم نأخذ كل عقدة شرطياً بآبائها. النتيجة: عيّنة من المشترك. الربط بالذكاء الاصطناعي: توليد بيانات اصطناعية.

مثال (6.16-10).

تعلّم المعاملات. المعطيات: البنية معلومة. المطلوب: تقدير اللواحق. الحل: الخطوة 1: كل عامل يُعلّم مستقلاً (مثل تردّدات في BN منفصلة). النتيجة: تقدير محلّي. الربط بالذكاء الاصطناعي: تقدير احتمالي معاملات الشبكة.

مثال (11-6.16).

تعلّم البنية. المعطيات: البيانات فقط. المطلوب: صعوبة المشكلة. الحل: الخطوة 1: البحث في فضاء DAGs معياراً (BIC/score) — صعب-NP تقريباً. النتيجة: يُحلّ بالإرشاد أو القيود. الربط بالذكاء الاصطناعي: اكتشاف السببية الآلي.

مثال (12-6.16).

الاستدلال بوجود دليل. المعطيات: رصدنا $C = c$. المطلوب: $p(A \mid c)$. الحل: الخطوة 1: نهمّش B بعد إدخال $C = c$ في العامل $p(C \mid B)$. النتيجة: توزيع محدّث. الربط بالذكاء الاصطناعي: تشخيص عكسي.

مثال (13-6.16).

ترميز الصفائح (Plate notation). المعطيات: عيّنات n متطابقة. المطلوب: تمثيل مختصر. الحل: الخطوة 1: نلفّ العقد المكرّرة بصفيحة مرقّمة n. النتيجة: رسم مضغوط. الربط بالذكاء الاصطناعي: توثيق نماذج الاحتمال.

مثال (14-6.16).

سببي مقابل ملاحَظ. المعطيات: تدخّل $do(X = x)$. المطلوب: الفرق. الحل: الخطوة 1: الملاحَظ $P(Y \mid X)$ يختلف عن التدخّل $P(Y \mid do(X))$ إلا في الرسوم القابلة للتعريف. النتيجة: السببية تحتاج do-calculus. الربط بالذكاء الاصطناعي: استدلال سببي في القرار.

مثال (15-6.16).

استخدام في النماذج العميقة. المعطيات: وحدات بايزية. المطلوب: أين تظهر BN؟ الحل: الخطوة 1: طبقات بايزية/VAE تستخدم تفكيكاً مشابهاً (5.16). النتيجة: جسر مع التعلم العميق. الربط بالذكاء الاصطناعي: deep Bayesian learning.

التعريف

dir="ltr"> <div

Definition 1.7.16 (Markov chain). A sequence $X_0, X_1, \ldots$ with $P(X_{t+1} \mid X_t) = P(X_{t+1} \mid X_0, \ldots, X_t)$ (memoryless). The transition matrix gives P with $P_{ij} = P(X_{t+1} = j \mid X_t = i)$. A distribution π is **stationary** if

$$\boldsymbol{\pi}^{\top} P = \boldsymbol{\pi}^{\top}, \qquad \pi_i \geq 0, \ \sum_i \pi_i = 1.$$

$$\boldsymbol{\pi}^{\top} P = \boldsymbol{\pi}^{\top}, \qquad \pi_i \geq 0, \ \sum_i \pi_i = 1. \tag{6.16}$$

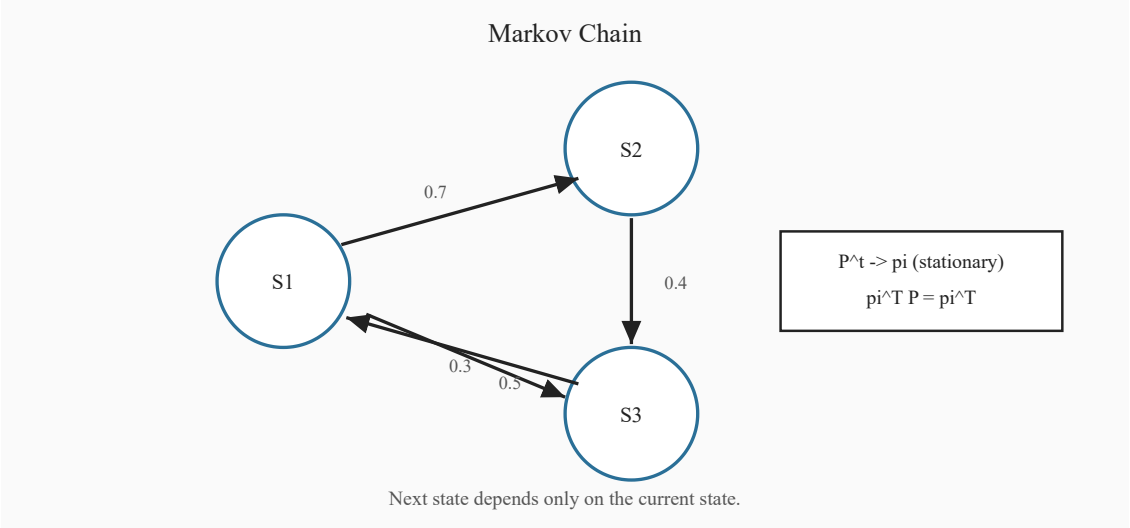
dir="ltr"> <div
the is It frequency. visit long-run the — chain the of point fixed the is (6.16) Equation intractable from draw to used Metropolis) (Gibbs, sampling MCMC of basis theoretical posteriors.

جدول الرموز

الرمز	الاسم	المعنى
P	مصفوفة الانتقال	احتمال الخطوة P_{ij}
π	التوزيع الثابت	$\pi P = \pi$
ergodic	عريض	تقارب لـ π
MCMC	مونت كارلو بالسلاسل	أخذ عيّنات لاحق

رسم توضيحي

<figure> الشكل<figcaption> 7.16: السلسلة: الحالة التالية تعتمد فقط على الحالية (لا ذاكرة). المصفوفة P تُولّد



شكل ٦.٠١٦: *
سلسلة ماركوف

التوزيع الثابت π لكل $\pi^\top P = \pi^\top$</figcaption>. </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط P بالتوزيع الثابت	مصفوفة مقابل متجه	π متجه، P مصفوفة
نسيان شرط التطبيع	π لا يجمع 1	قسّم على المجموع
افتراض التقارب دوماً	يحتاج عريضية	تحقّق من الحالة

أمثلة محلولة على سلاسل ماركوف (15 مثالاً)

مثال (1-7.16).

مصفوفة انتقال. المعطيات: حالتان برسم معلوم. المطلوب: اكتب P. الحل: الخطوة 1: $P = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$. النتيجة: مصفوفة انتقال. الربط بالذكاء الاصطناعي: نمذجة انتقال حالات المستخدم.

مثال (2-7.16).

خطوة n. المعطيات: P معلومة. المطلوب: $P(X_2 = j \mid X_0 = i)$. الحل: الخطوة 1: $(P^2)_{ij}$. النتيجة: مربّع المصفوفة. الربط بالذكاء الاصطناعي: احتمال الوصول بعد خطوات.

مثال (3-7.16).

التوزيع الثابت. المعطيات: P من (1-7.16). المطلوب: π. الحل: الخطوة 1: حل $\pi P = \pi$، $\pi_1 + \pi_2 = 1$: $0.7\pi_1 + 0.4\pi_2 = \pi_1 \Rightarrow 0.4\pi_2 = 0.3\pi_1$. النتيجة: $\pi = (4/7, 3/7) \approx (0.571, 0.429)$. الربط بالذكاء الاصطناعي: التوزيع طويل الأمد لحالات النظام.

مثال (4-7.16).

توازن تفصيلي (Detailed balance). المعطيات: $\pi_i P_{ij} = \pi_j P_{ji}$. المطلوب: ماذا يضمن؟ الحل: الخطوة 1: يضمن π ثابتاً (عكسي التوازن) $\Rightarrow$ تقارب. النتيجة: شرط كافٍ للثبات. الربط بالذكاء الاصطناعي: خوارزميات MCMC المقبولة.

مثال (5-7.16).

سلسلة عريضة (Ergodic). المعطيات: كل حالة تُبلَغ احتمالياً. المطلوب: النتيجة. الحل: الخطوة 1: عريضة + غير دورية $\Rightarrow$ تقارب لـ π بغضّ النظر عن البداية. النتيجة: توزيع فريد. الربط بالذكاء الاصطناعي: ضمان تقارب MCMC.

مثال (6-7.16).

PageRank كسلسلة. المعطيات: صفحات ووصلات. المطلوب: الصلة. الحل: الخطوة 1: المشي العشوائي على الروابط = سلسلة ماركوف؛ π = أهمّية الصفحة. النتيجة: ترتيب PageRank. الربط بالذكاء الاصطناعي: ترتيب محركات البحث.

مثال (7-7.16).

نموذج الطقس. المعطيات: غائم/مشمس بانتقالات. المطلوب: احتمال غائم بعد يومين. الحل: الخطوة 1: نرفع P للأسّ الثانية ونضرب في الحالة الحالية. النتيجة: احتمال متوقّع. الربط بالذكاء الاصطناعي: توقّع تسلسلي قصير

الأمد.

مثال (16.7-8).

تصنيف الحالات. المعطيات: حالة ممتصة. المطلوب: النتيجة بعيدة الأمد. الحل: الخطوة 1: سلسلة بامتصاص تقع حتماً في الممتص $\Rightarrow$ π مُركّزة هناك. النتيجة: مصير مؤكّد. الربط بالذكاء الاصطناعي: نماذج الوفاة/النجاح (absorbing).

مثال (16.7-9).

زمن الخلط (Mixing time). المعطيات: سلسلة بطيئة التقارب. المطلوب: ما أهمّية t_{mix}؟ الحل: الخطوة 1: عدد الخطوات حتى يقترب من π يحدّد جودة العيّنات. النتيجة: معيار فعالية MCMC. الربط بالذكاء الاصطناعي: تقليل زمن الخلط في الاستدلال.

مثال (16.7-10).

Metropolis كسلسلة (تمهيد). المعطيات: تقترح خطوة ثم تقبل/تطرح. المطلوب: لماذا سلسلة؟ الحل: الخطوة 1: سلسلة حالتها العيّنة، ثابتها اللاحق المستهدف. النتيجة: أساس MCMC (الفصل 18). الربط بالذكاء الاصطناعي: أخذ عيّنات من لاحق معقّد.

مثال (16.7-11).

حالات ممتصة. المعطيات: مصفوفة بكتلة ممتصة. المطلوب: التوزيع الثابت. الحل: الخطوة 1: π تتركّز على الحالة الممتصة (احتمالها 1). النتيجة: لا توزيع مختلط. الربط بالذكاء الاصطناعي: نماذج «النجاح النهائي».

مثال (16.7-12).

التوزيع الحدّي. المعطيات: سلسلة عريضة. المطلوب: $\lim_{t\to\infty} P(X_t = j)$. الحل: الخطوة 1: يؤول إلى π_j (بغضّ النظر عن البداية). النتيجة: π_j. الربط بالذكاء الاصطناعي: استقرار توقّع النظام.

مثال (16.7-13).

مُعيّن غيبس كسلسلة (تمهيد). المعطيات: نحدّث متغيّراً فرداً. المطلوب: الصلة. الحل: الخطوة 1: تسلسل التحديثات = سلسلة ماركوف بثابت اللاحق. النتيجة: عيّنات لاحقة. الربط بالذكاء الاصطناعي: sampling Gibbs (الفصل 18).

مثال (16.7-14).

مشي عشوائي متناظر. المعطيات: $P_{ij} = P_{ji}$. المطلوب: التوزيع الثابت. الحل: الخطوة 1: التوازن التفصيلي يحقّقه π المنتظم. النتيجة: π منتظم. الربط بالذكاء الاصطناعي: استكشاف متساوٍ للحالات.

مثال (16.7-15).

تشخيص التقارب. المعطيات: عيّنات MCMC. المطلوب: كيف نتأكّد؟ الحل: الخطوة 1: نفحص عدّة بدايات تتقارب لنفس π. (R-hat) النتيجة: ثقة بالعيّنات. الربط بالذكاء الاصطناعي: تقييم جودة أخذ العيّنات.

التعريف

dir="ltr"> <div

Field Random (Markov 1.8.16 Definition An **Gibbs).** c cliques with graph undirected :U_c potentials clique via distribution a defines

$$p(\mathbf{x}) = \frac{1}{Z}\exp\Big(-\sum_{c} U_c(\mathbf{x}_c)\Big), \qquad Z = \sum_{\mathbf{x}} e^{-\sum_c U_c(\mathbf{x}_c)}.$$

Markov the to equivalent is form Gibbs this states theorem **Hammersley–Clffiord** The energy Gibbs same the with (discriminative) $p(\mathbf{y} \mid \mathbf{x})$ models **CRF** A graph. the on property .x, y over

$$p(\mathbf{x}) = \frac{1}{Z}\exp\Big(-\sum_{c} U_c(\mathbf{x}_c)\Big), \qquad Z = \sum_{\mathbf{x}} e^{-\sum_c U_c(\mathbf{x}_c)}. \tag{7.16}$$

dir="ltr"> <div

stats) spatial denoising, (image MRFs of backbone energy-based the is (7.16) Equation chapter's this of hafl fields" "random the — prediction) structured labeling, (sequence CRFs and title.

جدول الرموز

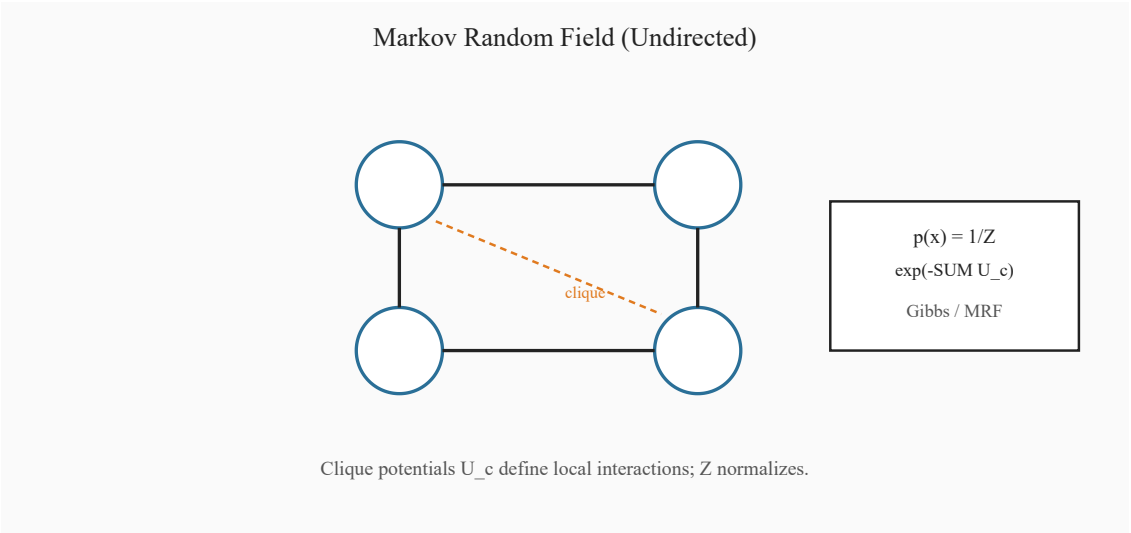
الرمز	الاسم	المعنى
U_c	كمون clique	طاقة تفاعل
Z	دالّة التقسيم	تطبيع (صعب الحساب)
CRF	حقل شرطي عشوائي	$p(y \mid x)$
Gibbs	توزيع غيبس	$\propto e^{-\text{energy}}$

رسم توضيحي

<figure> الشكل<figcaption> 8.16: الحقل العشوائي يربط العقد بأضلاع (كتل/cliques)؛ كل كتلة لها كمون U_c، والكثافة $p \propto e^{-\sum U_c}$ مع دالّة تقسيم Z. هذا أساس MRF وCRF.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
نسيان Z	لا تطبيع	احسب/قرّب Z
خلط MRF بـ CRF	مشترك مقابل شرطي	CRF يعلّم $p(y \mid x)$
إهمال الكتل غير الزوجية	طاقة أعلى رتبة	أدخلها إن لزم



شكل ٧.١٦: *
حقل عشوائي ماركوف

أمثلة محلولة على الحقول العشوائية (15 مثالاً)

مثال (8.16-1).

رسم غير موجّه وكتل. المعطيات: شبكة مربّعة بأضلاع. المطلوب: حدّد الكتل. الحل: الخطوة 1: الكتل هي الأضلاع (زوجية) في MRF زوجي. النتيجة: كتل حافة. الربط بالذكاء الاصطناعي: جيران البكسل في معالجة الصور.

مثال (8.16-2).

كمونات وكثافة. المعطيات: $U_c(x_c) = -\alpha x_i x_j$. المطلوب: شكل p. الحل: الخطوة 1: $p \propto e^{\alpha x_i x_j}$ يفضّل القيم المتّفقة (تنعيم). النتيجة: طاقة منخفضة = تكوين متماسك. الربط بالذكاء الاصطناعي: تنعيم صورة (denoising).

مثال (8.16-3).

هامرسلي–كليفورد. المعطيات: خاصّية ماركوف على الرسم. المطلوب: ماذا تضمن؟ الحل: الخطوة 1: تقابل غيبس $\Leftrightarrow$ ماركوف على نفس الرسم. النتيجة: نمذجة الطاقة معادلة للاستقلال المحلّي. الربط بالذكاء الاصطناعي: أساس نظري للرسوم الاحتمالية.

مثال (8.16-4).

نموذج إيزنغ (Ising). المعطيات: $U = -\sum_{ij} J s_i s_j - h \sum s_i$. المطلوب: الصلة بالفيزياء. الحل: الخطوة 1: طاقة إيزنغ = MRF زوجي على شبكة. النتيجة: نموذج سبين كلاسيكي. الربط بالذكاء الاصطناعي: نماذج توليدية مبكرة ورسوم.

مثال (8.16-5).

تنظيف صورة بـ MRF. المعطيات: صورة مُشوّشة. المطلوب: الفكرة. الحل: الخطوة 1: كمون بيانات (قرب الملاحظة) + كمون تنعيم (تناسق الجيران) ⇒ تقليل الطاقة يُنظّف. النتيجة: صورة مُصلَحة. الربط بالذكاء الاصطناعي: رسوم ماركوف للرؤية.

مثال (8.16-6).

دالّة التقسيم Z. المعطيات: رسم كبير. المطلوب: لماذا صعبة؟ الحل: الخطوة 1: $Z = \sum_x e^{-E(x)}$ مجموع على كل الإعدادات ⇒ صعب-#P. النتيجة: نقرّبها (MCMC/variational). الربط بالذكاء الاصطناعي: تدريب نماذج الطاقة.

مثال (8.16-7).

CRF لتوسيم تسلسل. المعطيات: كلمات x وتسميات y. المطلوب: شكل النموذج. الحل: الخطوة 1: $p(y \mid x) \propto \exp(\sum_k f_k(y_{i-1}, y_i, x) + \sum_i g_i(y_i, x))$. النتيجة: نموذج شرطي منظّم. الربط بالذكاء الاصطناعي: NER وتوسيم الجزء من الكلام (POS).

مثال (8.16-8).

CRF مقابل HMM. المعطيات: كلاهما لتسلسل. المطلوب: الفرق. الحل: الخطوة 1: HMM توليدي $p(x, y)$؛ CRF تمييزي $p(y \mid x)$ يسمح بميزات كثيرة. النتيجة: CRF أدقّ عادة. الربط بالذكاء الاصطناعي: اختيار نموذج التسلسل.

مثال (8.16-9).

دوال الميزات في CRF. المعطيات: ميزات انتقال/انبعاث. المطلوب: دورها. الحل: الخطوة 1: أوزان خطّية على ميزات تعلّم احتمال التسلسل. النتيجة: نموذج غنيّ بالميزات. الربط بالذكاء الاصطناعي: هندسة ميزات متقدّمة.

مثال (8.16-10).

كُتل زوجية مقابل أعلى رتبة. المعطيات: تفاعل ثلاثي. المطلوب: متى نحتاجها؟ الحل: الخطوة 1: الكُتل الزوجية تكفي غالباً؛ الأعلى رتبة تنمذج تفاعلات أعقد. النتيجة: حسب الدقة المطلوبة. الربط بالذكاء الاصطناعي: نماذج طاقة معقّدة.

مثال (8.16-11).

تقليل الطاقة. المعطيات: تكوين x. المطلوب: استنتاج MAP. الحل: الخطوة 1: $= \arg\max p(x)$ $\arg\min E(x)$ (تجاهل Z الثابت). النتيجة: حلّ مشكلة تحسين. الربط بالذكاء الاصطناعي: استدلال MAP كتحسين.

مثال (12-8.16).

نموذج بوتس (Potts). المعطيات: تجزئة صورة. المطلوب: الكمون. الحل: الخطوة 1: $U = -\beta \sum_{ij} \delta(y_i, y_j)$ يكافئ المناطق المتّحدة. النتيجة: تجزئة ناعمة. الربط بالذكاء الاصطناعي: segmentation.

مثال (13-8.16).

شرطي مقابل مشترك. المعطيات: CRF مقابل MRF. المطلوب: متى CRF؟ الحل: الخطوة 1: عندما المدخل x غني ونريد $p(y \mid x)$ فقط $\Rightarrow$ CRF أفضل. النتيجة: تجنّب نمذجة $p(x)$. الربط بالذكاء الاصطناعي: توقّع منظّم بمدخل غني.

مثال (14-8.16).

انتشار المعتقدات الحلقي (Loopy BP). المعطيات: رسم غير شجري. المطلوب: كيف نستدلّ؟ الحل: الخطوة 1: نمرّر رسائل تكرارية بين العقد (قد لا تتقارب لكنه عملي). النتيجة: تقريب للهامشيات. الربط بالذكاء الاصطناعي: استدلال تقريبي في الرسوم.

مثال (15-8.16).

MRF في الإحصاء المكاني والشبكات. المعطيات: بيانات جغرافية/رسوم بيانية. المطلوب: الصلة. الحل: الخطوة 1: الجيران يتشاركون طاقة $\Rightarrow$ نمذجة الاعتماد المكاني/البنيوي. النتيجة: GNN الحديث يعمّم هذا. الربط بالذكاء الاصطناعي: Networks Neural Graph كحقول عشوائية عصبية.

خيط الفصل

رفعنا الاحتمال الشرطي من أداة إلى إطار: (1.16) يعيد توزيع اليقين؛ (2.16) يدمج سابقاً بلاحظي لإنتاج لاحق؛ (3.16) يغلق التحديث لمترافقات؛ (4.16)–(5.16) يحلّلان المشترك عبر الاستقلال الشرطي؛ (6.16) يفكّكانه عبر بنية رسم بياني؛ (7.16) يصفان التطوّر عبر الزمن (ماركوف) وعبر الجوار (MRF/CRF) كلها ترتكز على التكامل (10)، الدفع (13)، والتغوار/المصفوفات (15).

جسور الكتاب

المفهوم	من الفصل	الاستخدام هنا
$\mathbb{P}_X$ والدفع	13 (2.13)	أساس التوزيعات
LOTUS والتغوار	15 (2.1/15.15)	توقّع اللاحق التنبّئي
المصفوفات الموجبة/التحليل	15 (4.15)	هيسيّة لابلاس، $J^\top J$
التكامل كقياس	10 (7.10)	حساب الدليل $p(x)$

الفصل 17 سينتقل إلى مترابحات التركيز (Concentration Inequalities) التي تُعطي حدوداً أقوى من تشيبيشِف للتعميم.

١. بـ (1.16) أثبت أنّ $P(A \mid B) + P(\neg A \mid B) = 1$.

٢. في اختبار طبّي، اشتقق $P(\text{سليم} \mid -)$ وعلّق على النتيجة.

٣. أثبت أنّ MAP لبرنولي = $(r+\alpha-1)/(n+\alpha+\beta-2)$.

٤. اشتقق $\sigma_n^{-2} = \sigma_0^{-2} + n/\sigma^2$ للحال الغاوسي (4-3.16).

٥. لـ Beta-Binomial، أوجد التوزيع اللاحق التنبّعي.

٦. بيّن أنّ L2 = سابق غاوسي (اربط 8-3.14 و9-3.16).

٧. لسلسلة $P = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}$ أوجد π.

٨. تحقّق من التوازن التفصيلي لـ P في التمرين 7.

٩. صف لماذا تفشل المترافقات في شبكة عصبية عميقة.

١٠. حوّل (4.16) إلى صيغة لوغاريتمية خطّية.

١١. في BN $A \to B \to C$، أثبت $A \perp C \mid B$.

١٢. اشرح «تفسير الظاهرة» بمثال من الطب.

١٣. لـ MRF زوجي، اكتب $p(x)$ وعلّق على Z.

١٤. فَرّق بين CRF و HMM في التوسيم.

١٥. أثبت أنّ $\pi^\top P = \pi$ لها حلّاً مجموعه 1 لسلسلة عريضة.

١٦. عبّر عن PageRank كـ $\pi^\top P = \pi$.

١٧. صف كيف يكون NB حالة خاصّة من BN.

١٨. لماذا Z في (7.16) صعبة الحساب وما البديل؟

١٩. اربط حقل غيبس بـ $J^\top J$ (معلومات/هيسيّة).

٢٠. صمّم BN صغيراً لتشخيص عطل في نظام واكتب تفكيكه.

هذا الفصل — الأغنى موضوعياً فأخذ **سبع نظريات** — ربط الاحتمال الشرطي بالاستدلال البايزي ثم بالبنية:

- **نظرية بايز** (1.16) تعيد توزيع اليقين بالدليل.
- **التقدير البايزي** (2.16) يفرّق السابق/اللاحظي/اللاحق/الدليل و MAP.
- **العائلات المترافقة** (3.16) تغلق التحديث لمعظم اللواحق الأسّية.
- **بايز الساذج** (4.16) يحلّل المشترك بافتراض الاستقلال ← مصنّف خطّي.

- **الشبكات البايزية** (5.16) تفكّك المشترك عبر رسم بياني و d-separation.
- **سلاسل ماركوف** (6.16) تحكم التطوّر بلا ذاكرة والتوزيع الثابت (أساس MCMC).
- **MRF/CRF** (7.16) تصف الحقول العشوائية بطاقة غيبس (صورة/تسلسل منظّم).

كلها ترتكز على التكامل (10)، الدفع (13)، LOTUS والتغوار (15)، وتُمهّد لـ MCMC والتعلّم البايزي (الفصلان 18–19).

الرمز	المعنى
$P(A \mid B)$	الاحتمال الشرطي
$p(\theta \mid x)$	اللاحق البايزي
MAP	أقصى لاحق
Beta, Gamma, Dir	سوابق مترافقة
P (مصفوفة)	مصفوفة انتقال ماركوف
π	التوزيع الثابت
Z, U_c	دالّة تقسيم وكمون غيبس

١. M. C. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006 (Ch. 8, 11).

٢. K. P. Murphy, *Machine Learning: A Probabilistic Perspective*, MIT Press, 2012 (Ch. 3, 17, 19).

٣. D. Koller, N. Friedman, *Probabilistic Graphical Models*, Press, MIT 2009.

٤. D. Barber, *Bayesian Reasoning and Machine Learning*, Cambridge, 2012.

٥. D. J. C. MacKay, *Information Theory, Inference, and Learning Algorithms*, Cambridge, 2003.

٦. C. Robert, G. Casella, *Monte Carlo Statistical Methods*, Springer, 2004.

٧. J. Pearl, *Causality*, Cambridge, 2009 (d-separation, do-calculus).

٨. M. J. Wainwright, M. I. Jordan, *Graphical Models, Exponential Families, and Variational Inference*, Now Publishers, 2008.

متراجحات التركيز (Concentration Inequalities)

«البياناتُ تَصْدَع، والاحتمالُ يَحْبِس: كم مرةً يمكن لعيّنةٍ واحدة أن تكذب؟»

متراجحات التركيز هي الأدوات التي تُحكِم قيداً كمّياً على احتمال أن يبتعد متغيّر عشوائي (أو متوسّط عيّنة) عن قيمته المتوقّعة أو عن توزيعه الحقيقي. في الذكاء الاصطناعي هي **العمود الفقري لنظرية التعلّم الإحصائي**: كل حدّ تعميم (PAC)، كل ضمانة لتقارب SGD، كل تحليل لاستقرار النموذج، وكل برهان على أن شبكة عميقة «لا تحفظ فقط» يعتمد على واحدةٍ منها على الأقل.

نسلسل في هذا الفصل سبع نظريات، يصعد كلٌّ منها عن سابقه في القوة أو في نطاق التطبيق:

- **2.17 ماركوف** — الحدّ الأوّل، يعتمد على المتوقّع فقط.
- **3.17 تشيبيشِف وكانتِلي** — يستخدم التباين (من الفصل 15).
- **4.17 تشيرنوف** — يستخدم الدالة المولّدة للحظات MGF (من الفصل 14).
- **5.17 هافدينغ واتحاد الاحتمالات** — للمجموع المقيدة، مع تصحيح بونفيرّوني.
- **6.17 برنشتاين** — يستفيد من تباين صغير ليحسّن هافدينغ.
- **7.17 أزوما وماكديارميد** — للمسيرات (martingales) والدوالّ ذات الفرق المحدود.
- **8.17 KL والانحراف المضاعف وسانوف** — القيد المعلوماتي الأقوى، أساس حدود PAC وحدود Rademacher.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

نفترض فضاء احتمال $(\Omega, \mathcal{F}, \mathbb{P})$ كما في الفصل 13، ومتغيّرات عشوائية $X, X_1, \dots, X_n$ بقيم حقيقية. نتعرّف على الرموز التي تتكرر:

الرمز	المعنى
$\mathbb{P}(A)$	احتمال الحدث A
$\mathbb{E}[X]$	المتوقّع (الوسيلة)
$\mu,\ \sigma^2$	المتوسط والتباين
$M_X(t)$	الدالة المولّدة للحظات $\mathbb{E}[e^{tX}]$
$\bar{X}_n$	المتوسط العيّني $\frac{1}{n}\sum_{i=1}^{n} X_i$
$D_{KL}(Q\|P)$	تباعد كولباك–لايبler
$\phi(t)$	دالة التوليد اللحظي $\log M_X(t)$

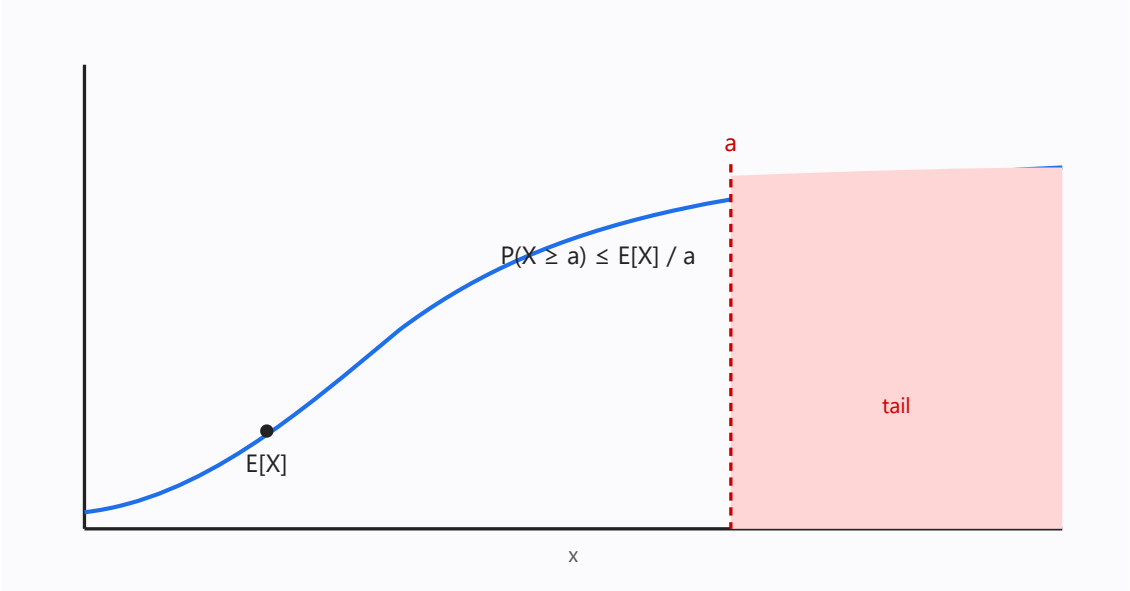
$$\mathbb{P}(X \geq a) \;\leq\; \frac{\mathbb{E}[X]}{a}, \qquad a > 0, \quad X \geq 0 \text{ عالمياً} \tag{1.17}$$

جدول الرموز

الرمز	المعنى	ملاحظة
X	متغيّر عشوائي غير سالب	شرط جوهري
a	عتبة موجبة	$a > 0$
$\mathbb{E}[X]$	المتوقّع	يحدّ الميلان

الرسم

<figure> الشكل<figcaption> 1.17: مساحة الذيل $\{X \geq a\}$ لا يمكن أن تتجاوز كتلة المتوقّع الموزّعة على كل



شكل ١٧.١: *
متراجحة ماركوف: مساحة الذيل فوق a محصورة بالمتوقع

المجال.</figcaption> </figure>

البرهان

لأن $X \geq 0$، فإن $X = X\mathbf{1}_{\{X \geq a\}} + X\mathbf{1}_{\{X<a\}} \geq X\mathbf{1}_{\{X \geq a\}} \geq a\,\mathbf{1}_{\{X \geq a\}}$. نأخذ المتوقّع:

$$\mathbb{E}[X] \geq \mathbb{E}[a\,\mathbf{1}_{\{X \geq a\}}] = a\,\mathbb{P}(X \geq a).$$

القسمة على $a > 0$ تعطي (1.17). ■

خمسة عشر مثالاً محلولاً

مثال (1-2.17): عمر خادوم ويب المعطيات: عمر خادوم جديد له متوسط 5 سنوات، ويُفترض غير سالب. المطلوب: حدّ أعلى لاحتمال ألّا يتجاوز عمره 20 سنة. الحل: الخطوة 1: نطبّق (1.17) بـ $a = 20$، $\mathbb{E}[X] = 5$. الخطوة 2: $\mathbb{P}(X \geq 20) \leq 5/20 = 0.25$. النتيجة: لا يتجاوز الاحتمال 25٪. الربط بالذكاء الاصطناعي: تقدير «وقت حتى العطل» (MTBF) لعُقد التدريب قبل شراء مزرعة GPU.

مثال (2-2.17): مطالبة تأمينية المعطيات: متوسط مطالبة 1000 وحدة نقدية، المطالبة غير سالبة. المطلوب: حدّ $\mathbb{P}(\text{مطالبة} \geq 10000)$. الحل: الخطوة 1: $a = 10000$، $\mu = 1000$. الخطوة 2: القيد $= 1000/10000 = 0.1$. النتيجة: ≤ 10٪. الربط بالذكاء الاصطناعي: نماذج تسعير المخاطر وتقدير الذيل لحسائر المحفظة.

مثال (17.2-3): زمن انتظار في طابور المعطيات: زمن انتظار وسطي 3 دقائق. المطلوب: $\mathbb{P}(\text{انتظار} \geq 15)$ دقيقة. الحل: الخطوة 1: $a = 15,\ \mu = 3$. الخطوة 2: $3/15 = 0.2$. النتيجة: $\leq$ ٢٠٪. الربط بالذكاء الاصطناعي: نمذجة زمن استجابة خدمة استدلال (inference latency) وسقف SLA.

مثال (17.2-4): حجم مجموعة بيانات المعطيات: متوسط حجم العيّنة المولّدة 50000 عيّة، غير سالب. المطلوب: $\mathbb{P}(\text{الحجم} \geq 200000)$. الحل: الخطوة 1: النسبة $50000/200000 = 0.25$. النتيجة: $\leq$ ٢٥٪. الربط بالذكاء الاصطناعي: تخطيط ميزانية جمع البيانات لتدريب نموذج لغوي.

مثال (17.2-5): استهلاك ذاكرة GPU المعطيات: استهلاك وسطي 4 جيجابايت، غير سالب. المطلوب: $\mathbb{P}(\text{الاستهلاك} \geq 16)$ جيجابايت. الحل: الخطوة 1: $4/16 = 0.25$. النتيجة: $\leq$ ٢٥٪. الربط بالذكاء الاصطناعي: تخصيص الذاكرة في حِزم الدُفعات (batch sizing) لتفادي تجاوز سعة البطاقة.

مثال (17.2-6): نسبة فقدان الحزم المعطيات: عدد الحزم المفقودة وسطياً 1.0 لكل ثانية، غير سالب. المطلوب: $\mathbb{P}(\text{فقد} \geq 1)$ حزمة/ث. الحل: الخطوة 1: $0.1/1 = 0.1$. النتيجة: $\leq$ ١٠٪. الربط بالذكاء الاصطناعي: موثوقية روابط نقل تدرّجات التدريب الموزّع.

مثال (17.2-7): استطاعة طاقة المعطيات: استطاعة وسطية 200 واط. المطلوب: $\mathbb{P}(\text{الاستطاعة} \geq 1000)$ واط. الحل: الخطوة 1: $200/1000 = 0.2$. النتيجة: $\leq$ ٢٠٪. الربط بالذكاء الاصطناعي: تقدير ذروة استهلاك مركز بيانات يحوي آلاف المسرّعات.

مثال (17.2-8): زمن تدريب نموذج المعطيات: زمن تدريب وسطي ساعتان. المطلوب: $\mathbb{P}(\text{الزمن} \geq 10)$ ساعات. الحل: الخطوة 1: $2/10 = 0.2$. النتيجة: $\leq$ ٢٠٪. الربط بالذكاء الاصطناعي: جدولة مهام التدريب على سحابة مشتركة مع ميزانية زمنية.

مثال (17.2-9): مبلغ تحويل المعطيات: متوسط مبلغ 50 وحدة. المطلوب: $\mathbb{P}(\text{المبلغ} \geq 500)$. الحل: الخطوة 1: $50/500 = 0.1$. النتيجة: $\leq$ ١٠٪. الربط بالذكاء الاصطناعي: كشف المعاملات الاحتيالية عبر عتبة المبلغ غير المربّحة.

مثال (17.2-10): معدّل خطأ نموذج المعطيات: معدّل خطأ وسطي 05.0 (غير سالب). المطلوب: $\mathbb{P}(\text{الخطأ} \geq 0.5)$. الحل: الخطوة 1: $0.05/0.5 = 0.1$. النتيجة: $\leq$ ١٠٪. الربط بالذكاء الاصطناعي: ضمانات موثوقية لنموذج مُحرَك في الإنتاج قبل النشر.

مثال (17.2-11): زمن كمون شبكة المعطيات: كمون وسطي 50 ميلّي ثانية. المطلوب: $\mathbb{P}(\text{الكمون} \geq 500)$ ميلّي ثانية. الحل: الخطوة 1: $50/500 = 0.1$. النتيجة: $\leq$ ١٠٪. الربط بالذكاء الاصطناعي: حدود زمن الاستجابة لنظام توصية في الوقت الحقيقي.

مثال (17.2-12): عمر بطارية جهاز طرفي المعطيات: عمر وسطي 8 ساعات. المطلوب: $\mathbb{P}(\text{العمر} \geq 24)$ ساعة. الحل: الخطوة 1: $8/24 \approx 0.333$. النتيجة: $\leq$ ٣٣٪. الربط بالذكاء الاصطناعي: أجهزة استشعار إنترنت الأشياء التي تُغذّي نماذج تنبؤية.

مثال (17.2-13): قراءة مستشعر المعطيات: قراءة وسطية 10 وحدات، غير سالبة. المطلوب: $\mathbb{P}(\text{القراءة} \geq 100)$. الحل: الخطوة 1: $10/100 = 0.1$. النتيجة: $\leq$ ١٠٪. الربط بالذكاء الاصطناعي: كشف الشذوذ في بيانات المستشعرات الصناعية.

مثال (17.2-14): عدد النقرات المعطيات: متوسط نقرات 3 لكل زيارة. المطلوب: $\mathbb{P}(\text{النقرات} \geq 30)$. الحل: الخطوة 1: $3/30 = 0.1$. النتيجة: $\leq$ ١٠٪. الربط بالذكاء الاصطناعي: تقدير أقصى حمل على خادم توصية إعلانية.

مثال (17.2-15): حجم ذاكرة تخزين مؤقّت مُهدَر المعطيات: حجم مُهدَر وسطي 2 جيجابايت. المطلوب: $\mathbb{P}(\text{المُهدَر} \geq 10)$ جيجابايت. الحل: الخطوة 1: $2/10 = 0.2$. النتيجة: $\leq$ ٢٠٪. الربط بالذكاء الاصطناعي: إدارة ذواكر التخزين المؤقّت لمجموعات التدريب الضخمة.

أخطاء شائعة

- تطبيق ماركوف على متغيّر قد يسلب: يجب تحويله أولاً (مثل $X = X^+$).
- نسيان شرط $a > 0$؛ القيد بلا معنى عند $a \le 0$.
- الخلط بين $\mathbb{P}(X \ge a)$ و $\mathbb{P}(X > a)$ — متساويان للمتصل، مختلفان للمنفصل.
- اعتبار القيد «تقديراً» لا «حدّاً أعلى» — قد يكون مُرخّصاً جداً.

$$\mathbb{P}\big(|X - \mu| \ge t\big) \;\le\; \frac{\sigma^2}{t^2}, \qquad t > 0 \tag{2.17}$$

النسخة أحادية الجانب (كانتِلي):

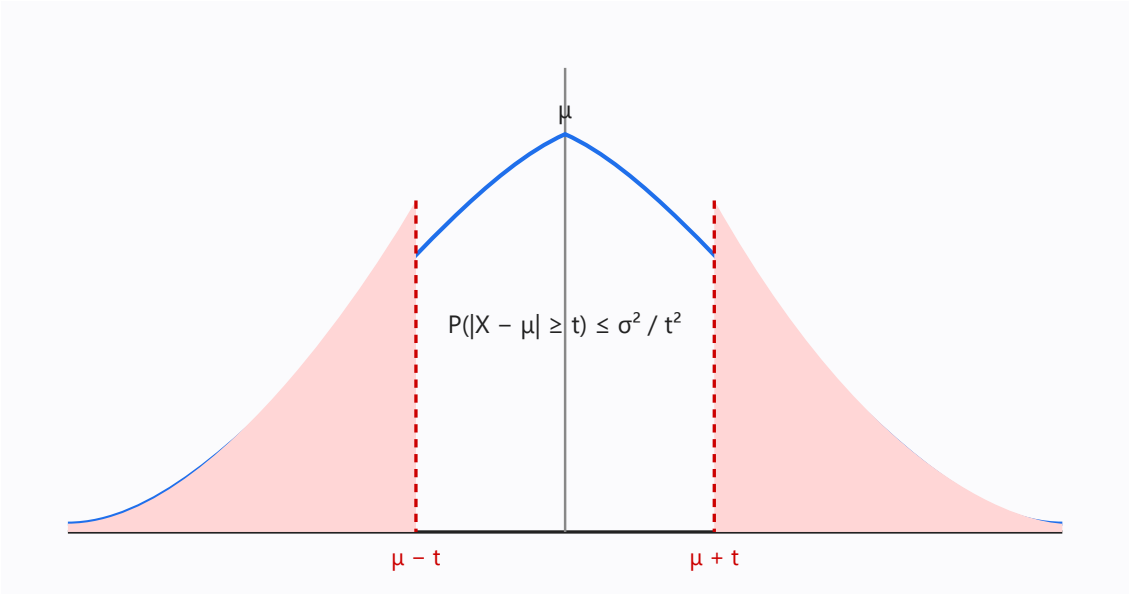
$$\mathbb{P}(X - \mu \ge t) \;\le\; \frac{\sigma^2}{\sigma^2 + t^2}, \qquad t > 0.$$

جدول الرموز

الرمز	المعنى
μ	$\mathbb{E}[X]$
σ^2	$\mathrm{Var}(X)$ من الفصل 15
t	عتبة الانحراف

الرسم

<figure> الشكل<figcaption> 2.17: احتمال الابتعاد أكثر من t عن الوسيط محصور بـ σ^2/t^2</figcaption>.



شكل ٢.١٧: *
متراجحة تشيبيشيف: الذيلان محصوران بالتباين على t مربع

</figure>

البرهان

نطبّق ماركوف (1.17) على المتغيّر غير السالب $Y = (X-\mu)^2$ ذي المتوقّع σ^2:

$$\mathbb{P}\big((X-\mu)^2 \ge t^2\big) \le \frac{\mathbb{E}[(X-\mu)^2]}{t^2} = \frac{\sigma^2}{t^2}.$$

و $\{(X-\mu)^2 \ge t^2\} = \{|X-\mu| \ge t\}$. النسخة أحادية تتبع من $\mathbb{E}[(X-\mu)^2] \ge \mathbb{P}(X-\mu \ge t)\, t^2 + \cdots$ $\mathbb{P}(X-\mu \ge t)\,\sigma^2$. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.17): درجة اختبار المعطيات: $\mu = 75$، $\sigma = 10$. المطلوب: $\mathbb{P}(|X-75| \ge 20)$. الحل: الخطوة 1: $t = 20$، $\sigma^2 = 100$. الخطوة 2: $100/400 = 0.25$. النتيجة: $\le$ 25٪. الربط بالذكاء الاصطناعي: تباين درجات مصنّف على بيانات اختبار عبر دُفعات.

مثال (2-3.17): دقّة نموذج المعطيات: دقّة وسطية 0.90، انحراف معياري 0.03. المطلوب: $\mathbb{P}(|\text{acc}-0.90| \ge 0.10)$. الحل: الخطوة 1: $\sigma^2 = 0.0009$، $t^2 = 0.01$. الخطوة 2: $0.0009/0.01 = 0.09$. النتيجة: $\le$ 9٪. الربط بالذكاء الاصطناعي: مراقبة استقرار دقّة نموذج منشور عبر الزمن.

مثال (3-3.17): معيار التدرّج المعطيات: $\|\nabla L\|$ متوسطه 0.1، انحرافه 0.2. المطلوب: $\mathbb{P}(\|\nabla L\| \ge 1.6)$. الحل: الخطوة 1: الانحراف عن الوسيط $t = 0.6$، $\sigma^2 = 0.04$. الخطوة 2: $0.04/0.36 \approx 0.111$. النتيجة: $\le$ 11.1٪. الربط بالذكاء الاصطناعي: كشف انفجار التدرّج (gradient explosion) أثناء التدريب.

مثال (4-3.17): مستشعر حرارة المعطيات: $\mu = 20°$، $\sigma = 2$. المطلوب: $\mathbb{P}(|T-20| \ge 6)$. الحل: الخطوة 1: $\sigma^2 = 4$، $t^2 = 36$. الخطوة 2: $4/36 \approx 0.111$. النتيجة: $\le$ 11.1٪. الربط بالذكاء الاصطناعي: كشف شذوذ المستشعر قبل إدخاله لنموذج تنبؤ.

مثال (5-3.17): عائد سهم المعطيات: عائد وسطي 0.05، تباين 0.01. المطلوب: $\mathbb{P}(|\text{return}| \ge 0.25)$. الحل: الخطوة 1: $\sigma^2 = 0.01$، $t^2 = 0.0625$. الخطوة 2: $0.01/0.0625 = 0.16$. النتيجة: $\le$ 16٪. الربط بالذكاء الاصطناعي: نماذج محافظ التعلّم المعزّز لتجنّب تذبذب العائد.

مثال (6-3.17): خسارة الدُفعة المعطيات: خسارة وسطية 0.30، انحراف 0.05. المطلوب: $\mathbb{P}(|\text{loss}-0.30| \ge 0.15)$. الحل: الخطوة 1: $\sigma^2 = 0.0025$، $t^2 = 0.0225$. الخطوة 2: $0.0025/0.0225 \approx 0.111$. النتيجة: $\le$ 11.1٪. الربط بالذكاء الاصطناعي: إنذار مبكّر عند خسارة دُفعة شاذة (فقدان تسمية).

مثال (7-3.17): بكسل صورة المعطيات: $\mu = 128$، $\sigma = 40$. المطلوب: $\mathbb{P}(|X-128| \ge 120)$. الحل: الخطوة 1: $\sigma^2 = 1600$، $t^2 = 14400$. الخطوة 2: $1600/14400 \approx 0.111$. النتيجة: $\le$ 11.1٪. الربط بالذكاء الاصطناعي: عتبة تنظيف البكسلات المعطوبة قبل التدريب.

مثال (8-3.17): معدّل الطلب المعطيات: $\mu = 100$ طلب/ث، $\sigma = 20$. المطلوب: $\mathbb{P}(|\text{rate}-100| \ge 50)$. الحل: الخطوة 1: $\sigma^2 = 400$، $t^2 = 2500$. الخطوة 2: $400/2500 = 0.16$. النتيجة: $\le$ 16٪. الربط بالذكاء الاصطناعي: ضبط سعة خادم استدلال تلقائياً (autoscaling).

مثال (9-3.17): مكوّن تضمين المعطيات: $\mu = 0$، $\sigma = 1$. المطلوب: $\mathbb{P}(|z| \ge 3)$ (قاعدة 3-سيغما). الحل: الخطوة 1: $\sigma^2 = 1$، $t^2 = 9$. الخطوة 2: $1/9 \approx 0.111$. النتيجة: $\le$ 11.1٪. الربط بالذكاء الاصطناعي: تنظيم التضمينات (embedding clipping) وتطبيع الميزات.

مثال (10-3.17): كانتِلي أحادي — خسارة مرتفعة المعطيات: $\mu = 0.20$، $\sigma = 0.05$، $t = 0.10$. المطلوب: $\mathbb{P}(\text{loss}-0.20 \ge 0.10)$. الحل: الخطوة 1: $\sigma^2 = 0.0025$. الخطوة 2: $0.0025/(0.0025+0.01) = 0.2$. النتيجة: $\le$ 20٪. الربط بالذكاء الاصطناعي: احتمال كارثة خسارة مرتفعة أحادي الجانب أدقّ من تشيبيشِف المتماثل.

مثال (11-3.17): كانتِلي — زمن استجابة المعطيات: $\mu = 0.2$ ث، $\sigma = 0.05$، نهتمّ بـ $0.3 \ge$. المطلوب: $\mathbb{P}(T - 0.2 \ge 0.1)$. الحل: الخطوة 1: $0.0025/(0.0025 + 0.01) = 0.2$. النتيجة: $\le$ 20٪. الربط بالذكاء

الاصطناعي: SLA أحادي الجانب لزمن استجابة خدمة.

مثال (12-3.17): انحراف دقّة منخفضة المعطيات: $\mu = 0.95$، $\sigma = 0.02$. المطلوب: $\mathbb{P}(\text{acc} \le 0.89)$ (أي $\mu - 0.06$). الحل: الخطوة 1: $t = 0.06$، $\sigma^2 = 0.0004$. الخطوة 2: $0.111 \approx 0.0004/0.0036$. النتيجة: $\le$ 11.1%. الربط بالذكاء الاصطناعي: تقارير انخفاض أداء نموذج دون العتبة المقبولة.

مثال (13-3.17): تباين تقديرية المعطيات: $\hat{\theta}$ تباينها 0.01، $\mu = 0$. المطلوب: $\mathbb{P}(|\hat{\theta}| \ge 0.2)$. الحل: الخطوة 1: $0.01/0.04 = 0.25$. النتيجة: $\le$ 25%. الربط بالذكاء الاصطناعي: عدم تجاوز تقدير معامل شبكة عتبة معيّنة.

مثال (14-3.17): طاقة حسابية المعطيات: $\mu = 500$ واط، $\sigma = 50$. المطلوب: $\mathbb{P}(|P - 500| \ge 150)$. الحل: الخطوة 1: $\sigma^2 = 2500$، $t^2 = 22500$. الخطوة 2: $0.111 \approx 2500/22500$. النتيجة: $\le$ 11.1%. الربط بالذكاء الاصطناعي: تخطيط قدرة لعُقد تدريب متعدّدة.

مثال (15-3.17): خطأ تقدير المتوسط المعطيات: لتقدير $\bar{X}$ بتباين σ^2/n، نريد $t = 0.05$ بتباين عيّني 0.0025. المطلوب: الحدّ الأعلى للخطأ. الحل: الخطوة 1: $1 = 0.0025/0.0025$ — قيد مرخّص؛ نقلّص t إلى 0.1: $0.25 = 0.0025/0.01$. النتيجة: لتحكّم أفضل نحتاج n أكبر. الربط بالذكاء الاصطناعي: اختيار حجم عيّنة كافٍ لتقدير مقياس جودة.

أخطاء شائعة

- نسيان أن تشيبيشِف يعطي حدّاً مُرخّصاً جداً لذيول التوزيعات الغاوسية.
- خلط σ و σ^2 في المقام (يُربّع t لا σ).
- استخدام النسخة المتماثلة حيث تكفي الأحادية فيعطي كانتِلي أفضل.
- الظن أن القيد يصلح لأي توزيع دون فرض وجود التباين المنتهي.

$$\mathbb{P}(X \ge a) \;\le\; \inf_{t>0} e^{-ta}\, M_X(t), \qquad M_X(t) = \mathbb{E}\big[e^{tX}\big] \tag{3.17}$$

جدول الرموز

الرمز	المعنى
$M_X(t)$	الدالة المولّدة للحظات (الفصل 14)
t	معامل الإمالة الأسّي (tilt)
a	العتبة

الرسم

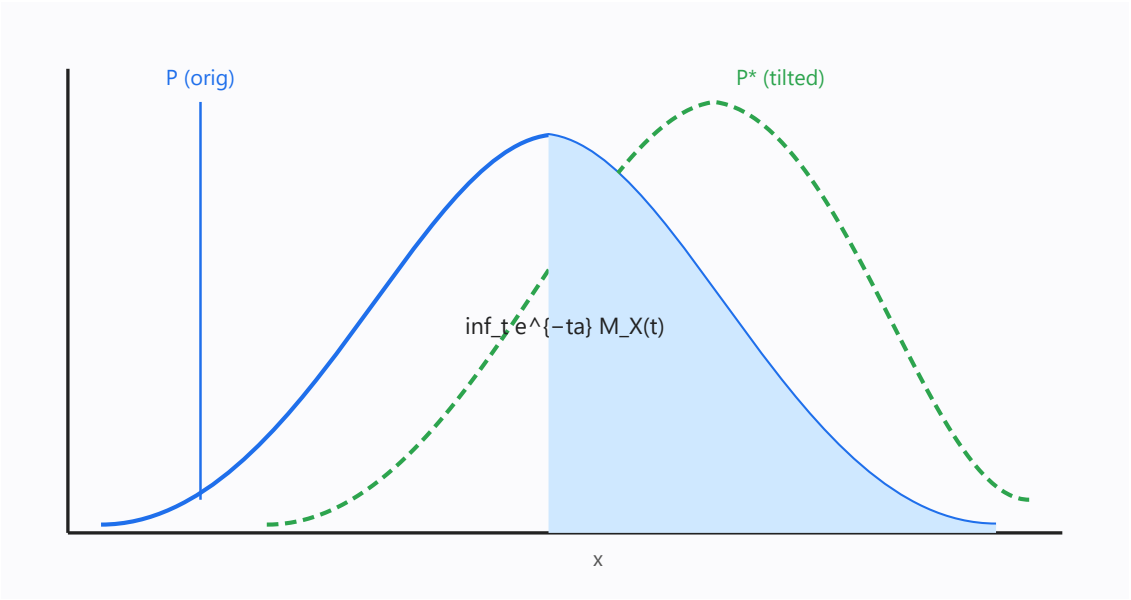
<figure> الشكل<figcaption> 3.17: اختيار $t > 0$ «يميل» التوزيع ليضيّق ذيلاً على حساب الآخر.</figcaption> </figure>

البرهان

لأي $t > 0$: $\mathbf{1}_{\{X \ge a\}} \le e^{t(X-a)}$ (لأن $X \ge a \Rightarrow t(X-a) \ge 0$). نأخذ المتوقّع:

$$\mathbb{P}(X \ge a) \le \mathbb{E}[e^{t(X-a)}] = e^{-ta} M_X(t).$$

نُحسِن بأخذ $\inf_{t>0}$. ■



شكل ٣.١٧: *
متراجحة تشيرنوف: الإمالة الأسّية تضيّق الذيل

خمسة عشر مثالاً محلولاً

مثال (1-4.17): مجموع بواسون المعطيات: $S_n \sim \text{Poisson}(n\lambda)$، $M(t) = e^{n\lambda(e^t-1)}$. المطلوب: $\mathbb{P}(S_n \geq n\lambda + \sqrt{n\lambda}\,u)$. الحل: الخطوة 1: نختار $t = \ln(1 + u/\sqrt{n\lambda})$ بإسقاط المشتقّة: t تقريباً. الخطوة 2: القيد $\exp(-u^2/2)$ (تقارب غاوسي). النتيجة: ذيل يقارب $\approx \exp(-u^2/2)$. الربط بالذكاء الاصطناعي: عدد الطلبات الواردة لنقطة نهاية تخدم نموذجاً.

مثال (2-4.17): رؤوس قطعة نقد (Binomial) المعطيات: $X \sim \text{Bin}(n,p)$، $M(t) = (1-p+pe^t)^n$. المطلوب: $\mathbb{P}(X \geq k)$ لـ $k > (1+\delta)np$. الحل: الخطوة 1: نُحلّ $e^{-tk}(1-p+pe^t)^n$. الخطوة 2: بـ $t^* = \ln \frac{k(1-p)}{p(n-k)}$ نحصل على قيد مضاعف (انظر 8.17). النتيجة: $\leq \left(\frac{np}{k}\right)^k \left(\frac{n(1-p)}{n-k}\right)^{n-k}$. الربط بالذكاء الاصطناعي: اختبار أهمّية لميزة ثنائية في شجرة قرار.

مثال (3-4.17): مجموع أسّي المعطيات: $X_i \sim \text{Exp}(\lambda)$ مستقلة، $M(t) = \frac{\lambda}{\lambda - t}$ لـ $t < \lambda$. المطلوب: $\mathbb{P}(\sum X_i \geq a)$. الحل: الخطوة 1: $M_\sum(t) = (\frac{\lambda}{\lambda-t})^n$. الخطوة 2: نُحسِن: $t = \lambda - \frac{n\lambda}{a}$ (بشرط $a > n$). النتيجة: $\leq \left(\frac{a}{n}\right)^n e^{-(a-n)}$. الربط بالذكاء الاصطناعي: زمن الفشل الكلي لنظام مكوّن من عُقد متوازية.

مثال (4-4.17): غاوسي عبر MGF (يعطي الإجابة الدقيقة) المعطيات: $X \sim \mathcal{N}(\mu, \sigma^2)$، $M(t) = e^{\mu t + \sigma^2 t^2/2}$. المطلوب: $\mathbb{P}(X \geq \mu + c\sigma)$. الحل: الخطوة 1: نُحسِن على t: $t^* = c/\sigma$. الخطوة 2: القيد $= e^{-c^2/2}$. النتيجة: $\mathbb{P}(X \geq \mu + c\sigma) \leq e^{-c^2/2}$. الربط بالذكاء الاصطناعي: متراجحة تشيبيشِف تُعطي $1/c^2$ بينما تشيرنوف $e^{-c^2/2}$ أقوى بكثير.

مثال (5-4.17): متغيّر مقيد [0,1] (تمهيد هافدينغ) المعطيات: $X_i \in [0,1]$، $\mathbb{E}[X_i] = p$. المطلوب: برهان قيد الأسّ e^{-2nt^2} بالإمالة. الحل: الخطوة 1: نستخدم $M_{X-p}(t) \leq e^{t^2/8}$ (عبر محدّبة log). الخطوة 2: على المجموع $M_\sum \leq e^{nt^2/8}$. النتيجة: $\mathbb{P}(\bar{X} - p \geq t) \leq e^{-2nt^2}$. الربط بالذكاء الاصطناعي: هذا يؤسّس هافدينغ (5.17) كحالة خاصة.

مثال (6-4.17): ضوضاء SGD المعطيات: تدرّجات لها متوسط ∇L وMGF محدودة. المطلوب: احتمال انحراف تحديث كبير. الحل: الخطوة 1: نطبّق تشيرنوف على مجموع ضوضاء الخطوة. الخطوة 2: معدّل اضمحلال خطوة يضبط t.

النتيجة: قيد أسّي على التذبذب حول المسار الحتمي. الربط بالذكاء الاصطناعي: براهين تقارب SGD شبه القطعي.

مثال (17.4-7): متغيّر شبه غاوسي (sub-Gaussian) المعطيات: X شبه غاوسي بوسيلة ν^2: $M(t) \le e^{\nu^2 t^2/2}$. المطلوب: $\mathbb{P}(X \ge a)$. الحل: الخطوة 1: $\inf_t e^{-ta+\nu^2 t^2/2} = e^{-a^2/(2\nu^2)}$. النتيجة: ذيل يشبه الغاوسي. الربط بالذكاء الاصطناعي: تحليل تقارب Adam/RMSProp بافتراض شبه غاوسية الضوضاء.

مثال (17.4-8): مجموع مستقل غير متطابق المعطيات: X_i لها $M_i(t)$ مختلفة. المطلوب: قيد على $\sum X_i$. الحل: الخطوة 1: $M_{\sum}(t) = \prod M_i(t)$. الخطوة 2: $\inf_t e^{-ta} \prod M_i(t)$. النتيجة: قيد يجمع لحظات كل طرف. الربط بالذكاء الاصطناعي: تجميع خصائص من طبقات شبكة مختلفة الأحجام.

مثال (17.4-9): اختبار نسبة الاحتمال المعطيات: إحصاء $\Lambda = \sum \log \frac{p_1}{p_0}(X_i)$. المطلوب: $\mathbb{P}_{H_0}(\Lambda \ge c)$. الحل: الخطوة 1: نأخذ $M_{\Lambda|H_0}(t)$ ونضبط t. النتيجة: حدّ أسّي لخطأ النوع الأول. الربط بالذكاء الاصطناعي: كشف التسمم في بيانات التدريب (data poisoning).

مثال (17.4-10): عدّ أحداث نادرة المعطيات: معدّل λ صغير، نهتم بتجاوز العتبة. المطلوب: $\mathbb{P}(N_\lambda \ge k)$ لـ $k \gg \lambda$. الحل: الخطوة 1: $M = e^{\lambda(e^t-1)}$. الخطوة 2: $t = \ln(k/\lambda)$ يعطي $\approx (e\lambda/k)^k$. النتيجة: ذيل أسّي في k. الربط بالذكاء الاصطناعي: كشف هجمات الحقن النادرة على مدخلات النموذج.

مثال (17.4-11): زمن إكمال مهام المعطيات: أزمنة مهام مستقلة بمتوسطات مختلفة. المطلوب: $\mathbb{P}(T \ge \text{الإجمالي})$. الحل: الخطوة 1: جداء الـ MGF. الخطوة 2: نُحسِن t. النتيجة: قيد على موعد التسليم. الربط بالذكاء الاصطناعي: جدولة خطوط أنابيب التدريب (pipelines).

مثال (17.4-12): مجموع أوزان المعطيات: أوزان $w_i \in [-1,1]$ بمتوسط 0. المطلوب: $\mathbb{P}(|\sum w_i X_i| \ge a)$. الحل: الخطوة 1: نستخدم حدّ هوفدينغ-تشيرنوف للمقيد. النتيجة: أسّي في $a^2/\sum w_i^2$. الربط بالذكاء الاصطناعي: استقرار تجميع نماذج (ensemble stability).

مثال (17.4-13): عتبة تنشيط المعطيات: مجموع مدخلات خلية عصبية $z \sim$ بمتوسط μ. المطلوب: $\mathbb{P}(z \ge 0)$ عند $\mu < 0$. الحل: الخطوة 1: تشيرنوف يعطي حدّاً أعلى دقيقاً للتفعيل الصفري. النتيجة: $\le e^{t\mu}$ عند اختيار t. الربط بالذكاء الاصطناعي: تحليل نسبة الخلايا «الميتة» (dead neurons).

مثال (17.4-14): تقدير كثافة المعطيات: k عيّة داخل نافذة. المطلوب: قيد على تجاوز العتبة. الحل: الخطوة 1: شبه ذاتي الحدّ عبر MGF تجميعي. النتيجة: أسّي في k. الربط بالذكاء الاصطناعي: نواة الكثافة في تقدير كثافة النواة (KDE) للبيانات.

مثال (17.4-15): متغيّر موجب بمتوسط معلوم فقط المعطيات: $X \ge 0$، $\mathbb{E}[X] = \mu$. المطلوب: $\mathbb{P}(X \ge m\mu)$. الحل: الخطوة 1: ماركوف يعطي $1/m$؛ تشيرنوف مع M مجهول يبقى عاماً. الخطوة 2: نستنتج أن المعرفة بلحظات أعلى تحسّن القيد. النتيجة: ماركوف هو حالة $t \to 0$ من تشيرنوف. الربط بالذكاء الاصطناعي: لماذا نفضّل bounds تستخدم التباين/MGF على ماركوف الخام.

أخطاء شائعة

- أخذ $t < 0$ لذيل علوي (يجب $t > 0$).
- نسيان أن inf فوق $t > 0$ قد يقع عند قيمة مغلقة الشكل فقط.
- الخلط بين $M_X(t)$ و $\mathbb{E}[X^k]$؛ الأولى دالة في t.
- اعتبار القيد قابلاً للوصول دائماً — للغاوسي نعم، لغيره قد يكون مرخّصاً.

$$\mathbb{P}\big(|\bar{X}_n - \mu| \geq t\big) \;\leq\; 2\exp\!\left(-\frac{2nt^2}{(b-a)^2}\right), \qquad X_i \in [a,b] \text{ مستقلة} \tag{4.17}$$

والاتحاد:

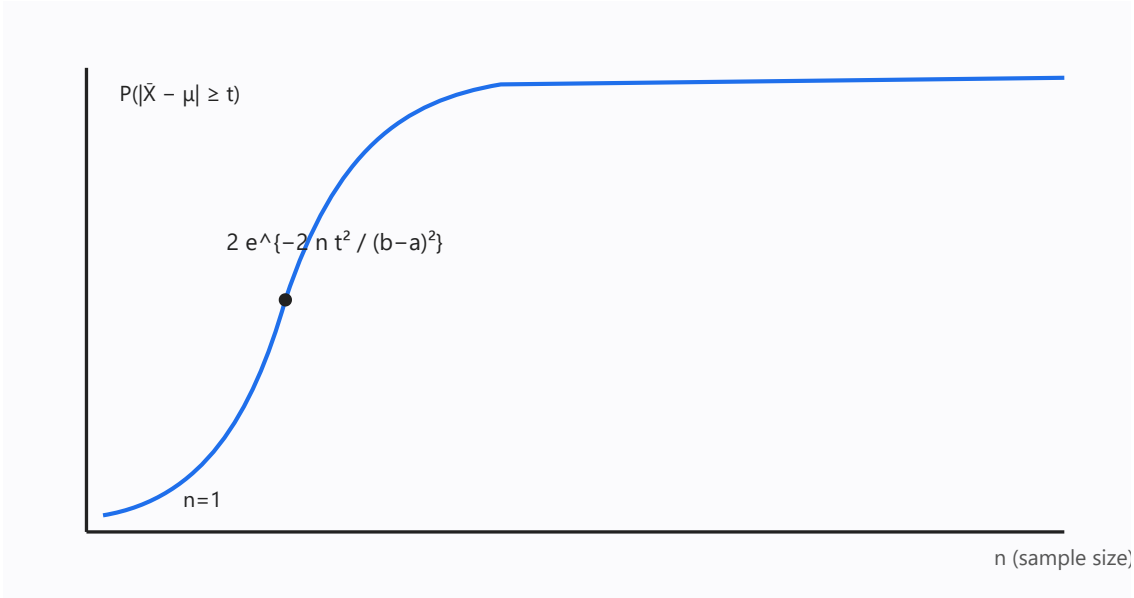
$$\mathbb{P}\left(\bigcup_{i=1}^{m} A_i\right) \;\leq\; \sum_{i=1}^{m} \mathbb{P}(A_i).$$

جدول الرموز

الرمز	المعنى
$[a,b]$	حاوية القيم
n	حجم العيّنة
m	عدد الأحداث في الاتحاد

الرسم

<figure> الشكل<figcaption> 4.17: احتمال انحراف المتوسط عن μ يتضاءل أسّياً مع n والفارق b −



شكل ٤.١٧: *
متراجحة هافدينغ: التضاؤل الأسّي للانحراف مع n

</figure> .</figcaption>a

البرهان (مخطّط)

للمتغيّر المقيد $Y_i = X_i - \mathbb{E}[X_i] \in [a-\mu, b-\mu]$، نستخدم محدّبة $\log M_{Y_i}(t) \leq \frac{t^2(b-a)^2}{8}$ (من تحزيز منحنى e^{tx} بين نقطتين). على المجموع $\log M_{\sum Y_i}(t) \leq \frac{nt^2(b-a)^2}{8}$؛ بتعيين $t = 4t/(b-a)^2$ نحصل على القيد. الاتحاد يتبع مباشرة من الإضافة للاحتمالات. ■

خمسة عشر مثالاً محلولاً

مثال (17.5-1): قطعة نقد عادلة المعطيات: $n = 1000$، $p = 0.5$، نهتم بـ $|\hat{p} - 0.5| \geq 0.05$. المطلوب: الحدّ الأعلى. الحل: الخطوة 1: $a = 0, b = 1, t = 0.05$. الخطوة 2: $2e^{-5} \approx 2\exp(-2 \cdot 1000 \cdot 0.0025/1) = 0.0135$. النتيجة: $\leq 1.35\%$. الربط بالذكاء الاصطناعي: دقّة مقدّرة من عيّنة تحقّق لاختبار نموذج.

مثال (17.5-2): تقدير دقّة نموذج المعطيات: $n = 10000$ عيّة، تسميات في $\{0, 1\}$، $t = 0.02$. المطلوب: قيد على انحراف الدقّة. الحل: الخطوة 1: $2e^{-8} \approx 0.00067 = 2\exp(-2 \cdot 10000 \cdot 0.0004)$. النتيجة: $\leq 0.67\%$. الربط بالذكاء الاصطناعي: فاصل ثقة محافظ لدقّة نموذج منشور.

مثال (17.5-3): اختبار A/B المعطيات: نسبتا تحويل في $[0, 1]$، $n = 2000$ لكل ذراع. المطلوب: قيد على $|p_A - p_B|$ بخطأ 0.03. الحل: الخطوة 1: لكل ذراع $2e^{-3.6} \approx 0.027$. الخطوة 2: بالاتحاد $\leq 2e^{-2 \cdot 2000 \cdot 0.0009}$. النتيجة: $\leq 5.4\%$ أن يخرف أيّ ذراع أكثر من 3%. الربط بالذكاء الاصطناعي: قرار نشر ميزة بناءً على تجربة A/B.

مثال (17.5-4): اتحاد على m نموذج المعطيات: نختبر $m = 10$ نموذجاً، كلٌّ بقيد ذيل 0.05. المطلوب: احتمال «فشل أيّ منها». الحل: الخطوة 1: الاتحاد: $10 \times 0.05 = 0.5$. النتيجة: 50% — خطر مقارنات متعدّدة. الربط بالذكاء الاصطناعي: اختيار النموذج من مرشّحات كثيرة يضخّم الخطأ.

مثال (17.5-5): تصحيح بونفيرّوني المعطيات: $m = 20$ اختباراً، نريد خطأ عائلي 0.05. المطلوب: العتبة لكل اختبار. الحل: الخطوة 1: العتبة لكل اختبار $0.05/20 = 0.0025$. النتيجة: نرفض عند $p<0.0025$. الربط بالذكاء الاصطناعي: اختيار الميزات عبر اختبارات كثيرة مع ضبط تعدّدي.

مثال (17.5-6): بحث مُفرط عن المعاملات المعطيات: $m = 50$ ضبطاً (hyperparameter)، قيد 0.04 لكل. المطلوب: احتمال اختيار سيّئ بالصدفة. الحل: الخطوة 1: الاتحاد $50 \times 0.04 = 2$ (نقول ≤ 1 بعد القص). النتيجة: الضبط المُفرط يبطل الضمانة. الربط بالذكاء الاصطناعي: why validation set must be held out (تسريب المعاملات).

مثال (17.5-7): متوسّط خسارة من دُفعات المعطيات: خسارة في $[0, 1]$، $n = 500$ دُفعة، $t = 0.05$. المطلوب: قيد المتوسط. الحل: الخطوة 1: $2e^{-2.5} \approx 0.164$. النتيجة: $\leq 16.4\%$ ضمن الدُفعة. الربط بالذكاء الاصطناعي: تقلّب الخسارة بين الدُفعات أثناء التدريب.

مثال (17.5-8): اتحاد على ميزات المعطيات: $m = 1000$ ميزة، قيد ذيل 0.001 لكل. المطلوب: احتمال انحراف أيّ ميزة. الحل: الخطوة 1: $1000 \times 0.001 = 1 \to \leq 1$ (نظرياً). النتيجة: الاتحاد مرخّص جداً هنا. الربط بالذكاء الاصطناعي: تطبيع الميزات لتقليل احتمال شذوذ أيّ بعد.

مثال (17.5-9): تقدير توزيع فئوي المعطيات: $K = 10$ فئات، $n = 5000$، $t = 0.01$. المطلوب: قيد على أكبر انحراف فئوي. الحل: الخطوة 1: لكل فئة $2e^{-2 \cdot 5000 \cdot 0.0001} = 2e^{-1} \approx 0.736$ (كبير). الخطوة 2: اتحاد على 10: ≤ 1. النتيجة: نحتاج n أكبر أو قيد أبطأ. الربط بالذكاء الاصطناعي: توازن عيّنة في تصنيف متعدّد الفئات.

مثال (17.5-10): قياس رضا المستخدمين المعطيات: تقييم في $[1, 5]$، نعيّر إلى $[0, 1]$، $n = 800$، $t = 0.05$. المطلوب: القيد. الحل: الخطوة 1: $2e^{-4} \approx 0.0366$. النتيجة: $\leq 3.66\%$. الربط بالذكاء الاصطناعي: مؤشّر رضا لتقييم منتج ذكاء اصطناعي.

مثال (17.5-11): كشف انحراف خادم المعطيات: زمن استجابة في $[0, 2]$ ث، $n = 300$ قياس، $t = 0.1$. المطلوب: قيد المتوسط. الحل: الخطوة 1: $(b - a)^2 = 4$. الخطوة 2: $2e^{-1.5} \approx 0.446 = 2e^{-2 \cdot 300 \cdot 0.01/4}$. النتيجة: $\leq 44.6\%$ — نطاق واسع، نزيد n. الربط بالذكاء الاصطناعي: مراقبة زمن استجابة خدمة استدلال.

مثال (17.5-12): تجميع أصوات المعطيات: $n = 100$ ناخب مستقل، رأي في $\{0, 1\}$. المطلوب: $\mathbb{P}(|\hat{p} - 0.5| \geq 0.1)$. الحل: الخطوة 1: $2e^{-2} \approx 0.27$. النتيجة: $\leq 27\%$. الربط بالذكاء $2e^{-2 \cdot 100 \cdot 0.01}$.

الاصطناعي: تجميع توقّعات نماذج كثيرة (ensemble voting).

مثال (5.17-13): اتحاد على طبقات المعطيات: 12 طبقة، كلٌّ بقيد ذيل 0.03. المطلوب: احتمال شذوذ أيّ طبقة. الحل: الخطوة 1: $12 \times 0.03 = 0.36$. النتيجة: $\leq 36\%$. الربط بالذكاء الاصطناعي: مراقبة استقرار كل طبقة شبكة أثناء التدريب.

مثال (5.17-14): عتبة اكتشاف anomaly المعطيات: نتيجة كاشف في $[0,1]$، $n = 2000$، $t = 0.04$. المطلوب: القيد. الحل: الخطوة 1: $2e^{-6.4} \approx 0.00166$. النتيجة: $\leq 0.166\%$. الربط بالذكاء الاصطناعي: ضبط عتبة كاشف شذوذ على تدفّق بيانات.

مثال (5.17-15): حجم عيّنة مطلوب المعطيات: نريد $\mathbb{P}(|\bar{X} - \mu| \geq 0.01) \leq 0.01$ لـ $X \in [0,1]$. المطلوب: n الأدنى. الحل: الخطوة 1: نحل $2e^{-2n(0.01)^2} \leq 0.005 \Rightarrow e^{-0.0002n} \leq 0.01$. الخطوة 2: $n \geq \ln(200)/0.0002 \approx 26490$. النتيجة: نحتاج ≈ 26500 عيّة. الربط بالذكاء الاصطناعي: تقدير ميزانية وسم لضمان دقّة مقدّرة.

أخطاء شائعة

- نسيان عامل 2 للذيلين (المتماثل).
- إدخال $(b-a)$ بدل $(b-a)^2$ في المقام.
- استخدام الاتحاد مباشرة على m كبير فيعطي قيداً >1 (مرخّص جداً).
- افتراض الاستقلال عند وجود ارتباط بين العيّنات.

ليكن X_i مستقلة، $|X_i| \leq b$، و $\sigma^2 = \frac{1}{n}\sum \mathrm{Var}(X_i)$. فعندئذٍ:

$$\mathbb{P}\left(\sum_{i=1}^{n} X_i \geq t\right) \leq \exp\left(-\frac{t^2}{2\left(n\sigma^2 + bt/3\right)}\right) \tag{5.17}$$

جدول الرموز

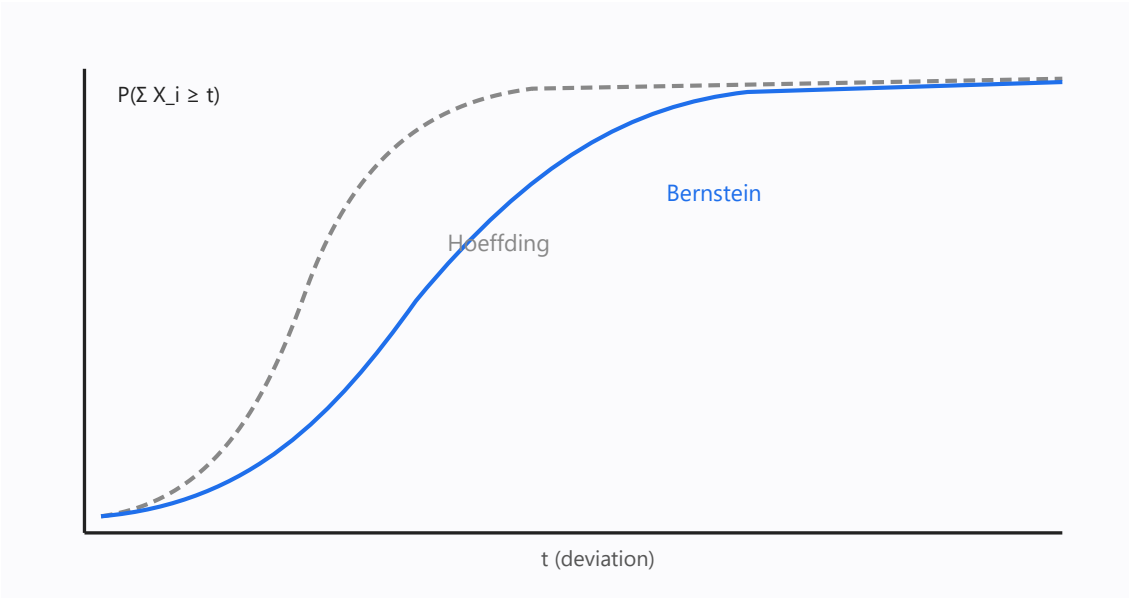
الرمز	المعنى
b	حدّة القيمة المطلقة
σ^2	متوسط التباينات
t	عتبة المجموع

الرسم

<figure>الشكل 5.17: برنشتاين تشدّد القيد حين يكون التباين صغيراً مقارنة بالحدّ b.</figcaption>
</figure>

البرهان (مخطّط)

نستعين بلحظة ثالثة محدودة: $|X_i| \leq b \Rightarrow \mathbb{E}[X_i^k] \leq \frac{k!}{2} b^{k-2}\mathrm{Var}(X_i)$ لـ $k \geq 2$. بتوسيع $M_{X_i}(t)$ ونجمع على i، ثمّ نضبط t نحصل على (5.17). عند $n\sigma^2 \gg bt$ يقترب من حدّ غاوسي $\exp(-t^2/2n\sigma^2)$، أقوى من هافدينغ. ■



شكل ٥.١٧: *
متراجحة برنشتاين: أفضل من هافدينغ عند تباين صغير

خمسة عشر مثالاً محلولاً

مثال (1-6.17): مجموع بمتوسط تباين صغير المعطيات: $n = 1000$، $|X_i| \le 1$، $\sigma^2 = 0.01$، $t = 10$. المطلوب: قيد برنشتاين مقابل هافدينغ. الحل: الخطوة 1: برنشتاين: $\exp(-100/(2(10 + 10/3))) = \exp(-100/26.67) \approx e^{-3.75} \approx 0.0235$. الخطوة 2: هافدينغ: $\exp(-2 \cdot 100/4) = e^{-50} \approx 1.9 \times 10^{-22}$ — لكن هافدينغ هنا تستخدم $(b-a)^2 = 4$ للمقيد ضمن $[-1, 1]$ بمتوسط 0 $\Rightarrow$ أقوى فعلاً. نلاحظ برنشتاين يفيد حين t صغير نسبياً. النتيجة: على الذيل المتوسّط يفوز التباين. الربط بالذكاء الاصطناعي: تقدير مجموع تدرّجات صغيرة التباين.

مثال (2-6.17): قصّ التدرّج (clipping) المعطيات: تدرّجات مقصوصة عند $b = 1$، $\sigma^2 = 0.25$، $n = 500$، $t = 20$. المطلوب: قيد المجموع. الحل: الخطوة 1: $\exp(-400/(2(125 + 20/3))) = \exp(-400/263.3) \approx e^{-1.52} \approx 0.218$. النتيجة: $\le 21.8\%$. الربط بالذكاء الاصطناعي: تحليل استقرار تدرّج مقصوص (gradient clipping).

مثال (3-6.17): ضوضاء مستشعر منخفضة المعطيات: $|X_i| \le 0.1$، $\sigma^2 = 0.001$، $n = 100$، $t = 0.5$. المطلوب: القيد. الحل: الخطوة 1: $\exp(-0.25/(2(0.1 + 0.05/3))) = \exp(-0.25/0.233) \approx e^{-1.07} \approx 0.343$. النتيجة: $\le 34.3\%$. الربط بالذكاء الاصطناعي: ترشيح ضوضاء لبيانات مستشعرات قبل التدريب.

مثال (4-6.17): مجموع أرجح من هافدينغ المعطيات: $\sigma^2 = 0.001$، $b = 1$، $n = 10^4$، $t = 5$. المطلوب: برنشتاين. الحل: الخطوة 1: $\exp(-25/(2(10+5/3))) = \exp(-25/23.3) \approx e^{-1.07} \approx 0.343$. النتيجة: برنشتاين أفضل لأن $n\sigma^2$ يطغى. الربط بالذكاء الاصطناعي: تجميع تقديرات دقّة من عيّنات كثيرة منخفضة التباين.

مثال (5-6.17): أخطاء تصنيف ثنائي المعطيات: $X_i \in \{-1, 1\}$، $\sigma^2 = 1$، $b = 1$، $n = 2000$، $t = 50$. المطلوب: قيد الفائض. الحل: الخطوة 1: $\exp(-2500/(2(2000 + 50/3))) \approx e^{-0.619} \approx 0.538$. النتيجة: $\le 53.8\%$ (مرخّص، نخفّض t). الربط بالذكاء الاصطناعي: هامش خطأ المصنّف (margin theory). preview

مثال (6-6.17): تباين كبير المعطيات: $\sigma^2 = 4$، $b = 1$ (غير متماسك — $\sigma^2 > b^2$ مستحيل)؛ نصحّح $b = 3$. المطلوب: مع $n = 500, t = 30$. الحل: الخطوة 1: $\exp(-900/(2(2000 + 30/3))) = \exp(-900/2020) \approx 0.64$. النتيجة: $\le 64\%$. الربط بالذكاء الاصطناعي: بيانات عالية التباين تتطلّب عيّنات أكبر.

مثال (7-6.17): قياس تداخل (overlap) المعطيات: $n = 300$، $\sigma^2 = 0.05$، $b = 0.5$، $t = 3$. المطلوب:

القيد. الحل: الخطوة 1: $\exp(-9/(2(15+1.5/3))) = \exp(-9/31) \approx e^{-0.29} \approx 0.748$. النتيجة: $\le$ 74.8٪. الربط بالذكاء الاصطناعي: قياس تداخل تنبؤات نماذج للاندماج.

مثال (17.6-8): انحراف خسارة إجمالية المعطيات: $\sigma^2 = 0.02$، $b = 1$، $n = 2000$، $t = 10$. المطلوب: قيد. الحل: الخطوة 1: $\exp(-100/(2(40+10/3))) = \exp(-100/46.67) \approx e^{-2.14} \approx 0.117$. النتيجة: $\le$ 11.7٪. الربط بالذكاء الاصطناعي: تذبذب الخسارة الكليّة حول المتوقّع.

مثال (17.6-9): تباين يُقدَّر من البيانات المعطيات: نستبدل σ^2 بتقدير العيّنة $\hat\sigma^2 = 0.1$. المطلوب: هل يبقى القيد صالحاً؟ الحل: الخطوة 1: برنشتاين يفترض σ^2 معلومة؛ نستخدم نسخة ذاتية (sefl-bounding) أو نزيد العتبة. النتيجة: بحاجة لقيد «بيانات مدفوعة». الربط بالذكاء الاصطناعي: عدم اليقين في تباين التدريب الفعلي.

مثال (17.6-10): تدرّج متفرّق (sparse) المعطيات: معظم $X_i = 0$، قلة غير صفر بـ $|X_i| \le 1$، $\sigma^2 = 0.0005$. المطلوب: قيد مجموع غير صفري. الحل: الخطوة 1: التباين الصغير يشدّد القيد كثيراً. النتيجة: برنشتاين يتفوّق بشدّة على هافدينغ. الربط بالذكاء الاصطناعي: تحديثات متفرّقة في محسّنات مثل Adam.

مثال (17.6-11): مجموع أوزان طبقة المعطيات: أوزان مقصوصة $b = 2$، $\sigma^2 = 0.5$، $n = 784$، $t = 40$. المطلوب: قيد تنشيط. الحل: الخطوة 1: $\exp(-1600/(2(392+80/3))) = \exp(-1600/437.3) \approx e^{-3.66} \approx 0.026$. النتيجة: $\le$ 2.6٪. الربط بالذكاء الاصطناعي: استقرار مجموع مدخلات طبقة كثيفة.

مثال (17.6-12): قيم موجبة فقط المعطيات: $X_i \in [0,1]$، $\sigma^2 = 0.04$، $n = 500$، $t = 10$. المطلوب: قيد. الحل: الخطوة 1: $\exp(-100/(2(20+10/3))) = \exp(-100/46.67) \approx e^{-2.14} \approx 0.117$. النتيجة: $\le$ 11.7٪. الربط بالذكاء الاصطناعي: احتمال تجاوز مجموع احتمالات softmax عتبة.

مثال (17.6-13): إشارة تراكمية المعطيات: $\sigma^2 = 0.1$، $b = 0.5$، $n = 1000$، $t = 8$. المطلوب: قيد. الحل: الخطوة 1: $\exp(-64/(2(100+8/3))) = \exp(-64/205.3) \approx e^{-0.312} \approx 0.732$. النتيجة: $\le$ 73.2٪. الربط بالذكاء الاصطناعي: تراكم إشارات في شبكة عصبية عميقة.

مثال (17.6-14): تحسين العتبة المعطيات: نريد ≤ 0.05، $\sigma^2 = 0.01$، $b = 1$، $n = 1000$. المطلوب: t الأقصى المسموح. الحل: الخطوة 1: نحل $\exp(-t^2/(2(10+t/3))) = 0.05 \Rightarrow t^2/(20+2t/3) \approx 3 \Rightarrow t \approx 8.2$. النتيجة: $t \lesssim 8.2$. الربط بالذكاء الاصطناعي: ضبط عتبة إنذار لنظام إنتاجي.

مثال (17.6-15): مقارنة مع تشيبيشف المعطيات: نفس n, σ^2, t أعلاه. المطلوب: قيد تشيبيشف المتماثل للمجموع. الحل: الخطوة 1: $\mathrm{Var}(\sum) = n\sigma^2 = 10$، $t = 8 \Rightarrow 0.156 = 10/64$. النتيجة: تشيبيشف 15.6٪ مقابل برنشتاين 5٪. الربط بالذكاء الاصطناعي: برنشتاين أدقّ لأنه يستخدم الحدّ b.

أخطاء شائعة

- المبالغة في التباين: يجب $\sigma^2 \le b^2$ للمتغيّر المقيد.
- نسيان عامل $t/3$ في المقام.
- الخلط بين برنشتاين لـ «المجموع» وهافدينغ لـ «المتوسط» دون إعادة القياس.
- استخدام σ^2 المقدّرة من البيانات دون نسخة ذاتية الحدّ.

أزوما: إن كانت M_k مسيرة بفروق مقيدة $|M_k - M_{k-1}| \le c_k$ (وبشرط $\mathbb{E}[M_k | M_{k-1}] = M_{k-1}$، أي مسيرة)، فـ

$$\mathbb{P}\big(|M_n - M_0| \ge t\big) \le 2\exp\!\left(-\frac{t^2}{2\sum_{k=1}^{n} c_k^2}\right). \tag{6.17}$$

ماكديارميد (الفرق المحدود): إن كانت f تحقّق $|f(x) - f(x')| \le c_i$ متى اختلفت المعامل i فقط، فـ

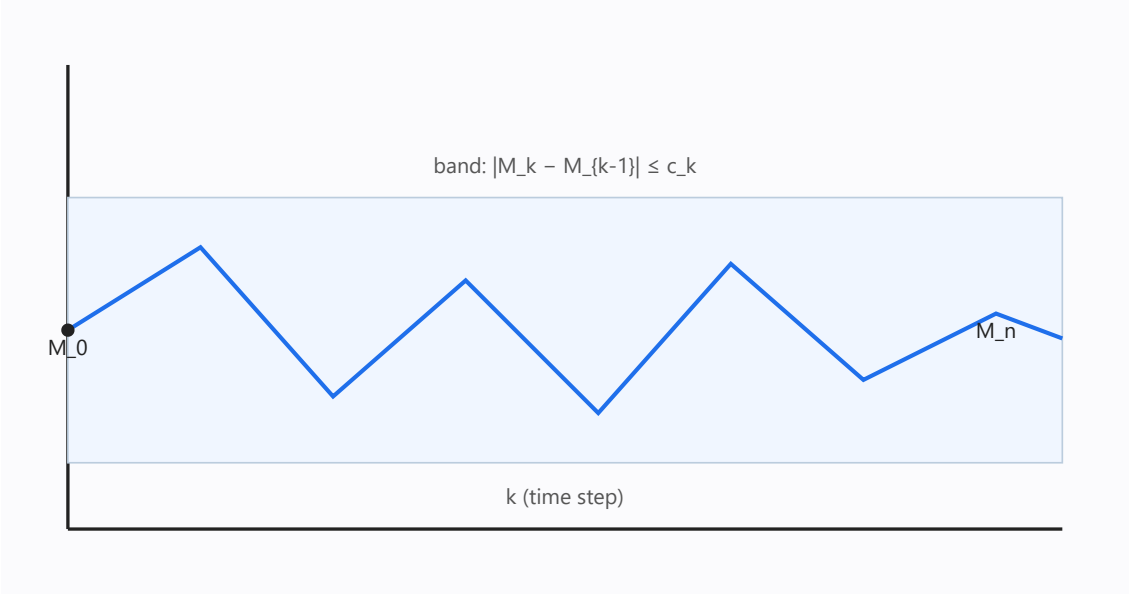
$$\mathbb{P}\big(|f(X_1,\dots,X_n) - \mathbb{E}f| \ge t\big) \le 2\exp\!\left(-\frac{2t^2}{\sum_{i=1}^{n} c_i^2}\right).$$

جدول الرموز

الرمز	المعنى
M_k	مسيرة عند الخطوة k
c_k	حدّة الفرق
f	دالة متماسكة محلياً

الرسم

<figure> الشكل<figcaption> 6.17: المسيرة لا تتأرجح بعيداً عن بدايتها أكثر مما تسمح الخطوات المقيدة.</figcaption>



شكل ٦.١٧: *
مسيرة أزوما: خطوات مقيدة تحصر الانحراف

</figure>

البرهان (مخطّط)

نطبّق تشيرنوف على المسيرة: لـ $t > 0$، $\mathbb{E}[e^{t(M_k - M_{k-1})}|M_{k-1}] \le e^{t^2 c_k^2/2}$ (عبر حدّ هوفدينغ على الفرق المقيد). بضرب التوقعات الشرطية وضرب المتسلسلة نحصل على $M_{M_n - M_0}(t) \le \exp(t^2 \sum c_k^2/2)$، ثمّ تشيرنوف يعطي (6.17). ماكديارميد يتبع بربط f بمسيرة القيم المشروطة $\mathbb{E}[f|X_1,\dots,X_k]$. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.17): مشي عشوائي مقيد المعطيات: $M_k - M_{k-1} \in \{-1, 1\}$، إذن $c_k = 1$، $n = 100$. المطلوب: $\mathbb{P}(|M_{100}| \ge 20)$. الحل: الخطوة 1: $2\exp(-400/(2\cdot 100)) = 2e^{-2} \approx 0.27$. النتيجة: $\le 27\%$. الربط بالذكاء الاصطناعي: تذبذب تراكمي في تحديثات معاملات متفرّقة.

مثال (17.7-2): دقّة كدالة للعيّنة (استقرار) المعطيات: $= f$ دقّة النموذج، تغيير عيّنة واحدة يغيّر الدقّة بحدّ $c_i = 1/n$. المطلوب: قيد انحراف الدقّة. الحل: الخطوة 1: $n(1/n)^2 = 1/n$ = $\sum c_i^2$. الخطوة 2: $2\exp(-2t^2/(1/n)) = 2\exp(-2nt^2)$. النتيجة: أسّي حادّ في n. الربط بالذكاء الاصطناعي: نظرية الاستقرار (Stability Generalization) $\rightarrow$ لـ Bousquet–Elisseeff.

مثال (17.7-3): خطأ إزالة عيّنة واحدة (leave-one-out) المعطيات: تغيير عيّنة واحدة يحرّك الخسارة بـ $c = 1/n$. المطلوب: قيد التفاوت. الحل: الخطوة 1: نفس القيد $2e^{-2nt^2}$. النتيجة: تفاوت صغير لـ n كبير. الربط بالذكاء الاصطناعي: ارتباط الاستقرار بضمانات التعميم (الفصل 30 لاحقاً).

مثال (17.7-4): مجموع أوزان مقيد الخطوات المعطيات: تحديث أوزان $|\Delta w_k| \le 0.1$، $n = 500$. المطلوب: $\mathbb{P}(|\sum \Delta w| \ge 2)$. الحل: الخطوة 1: $500 \times 0.01 = 5$ = $\sum c_k^2$. الخطوة 2: $2\exp(-4/(2\cdot 5)) = 2e^{-0.4} \approx 1.34$ (نقول ≤ 1). النتيجة: مرخّص، نخفّض t إلى 1: $2e^{-0.1} \approx 1.81 \rightarrow \le 1$. الربط بالذكاء الاصطناعي: تراكم تحديثات صغيرة في محسّن.

مثال (17.7-5): مسيرة سعر أصل المعطيات: تغيّر سعر يومي مقيد بـ $c = 0.05$، $n = 250$ يوم. المطلوب: $\mathbb{P}(|\text{السعر النهائي} - \text{الأول}| \ge 1)$. الحل: الخطوة 1: $250 \times 0.0025 = 0.625$ = $\sum c_k^2$. الخطوة 2: $2\exp(-1/(2\cdot 0.625)) = 2e^{-0.8} \approx 0.899$. النتيجة: $\le 89.9\%$ — مقيدة واسعة، السوق غير مسيرة حقاً. الربط بالذكاء الاصطناعي: تحذير: أسواق المال لا تتبع افتراض المسيرة.

مثال (17.7-6): تدرّج بخطوات مقيدة المعطيات: $|\nabla_i L| \le 1$، $n = 1000$ تحديث. المطلوب: قيد انحراف مجموع التدرّج. الحل: الخطوة 1: $2\exp(-t^2/(2\cdot 1000))$. النتيجة: عند $t = 20$: $2e^{-0.2} \approx 1.64 \rightarrow \le 1$. الربط بالذكاء الاصطناعي: تحليل تقارب GD على دالّة مقيدة التدرّج.

مثال (17.7-7): ماكديارميد على متوسط المعطيات: $f = \bar{X}$، تغيير عيّنة واحدة يحرّك $\bar{X}$ بـ $c_i = (b-a)/n$. المطلوب: استنتاج هافدينغ. الحل: الخطوة 1: $n((b-a)/n)^2 = (b-a)^2/n$ = $\sum c_i^2$. الخطوة 2: $2\exp(-2t^2/((b-a)^2/n)) = 2\exp(-2nt^2/(b-a)^2)$. النتيجة: يطابق (17.4). الربط بالذكاء الاصطناعي: هافدينغ حالة خاصة من ماكديارميد.

مثال (17.7-8): خطأ تقدير الكثافة المعطيات: تغيير نقطة يحرّك تقدير الكثافة بـ $c_i = 1/(nh^d)$. المطلوب: قيد. الحل: الخطوة 1: $\sum c_i^2 = 1/(nh^{2d})$. النتيجة: $2\exp(-2t^2 nh^{2d})$. الربط بالذكاء الاصطناعي: استقرار مقدّر الكثافة النوائية.

مثال (17.7-9): تجميع أصوات نماذج المعطيات: تغيير رأي نموذج واحد يحرّك التصويت بـ $1/n$. المطلوب: قيد انحراف التصويت. الحل: الخطوة 1: نفس $2e^{-2nt^2}$. النتيجة: ensemble مستقرّ لـ n كبير. الربط بالذكاء الاصطناعي: لماذا التجميع (voting) يقلّل التباين.

مثال (17.7-10): تدرّج عشوائي SGD كمسيرة المعطيات: الضوضاء مقيدة بـ c لكل خطوة. المطلوب: قيد انحراف المسار. الحل: الخطوة 1: $2\exp(-t^2/(2nc^2))$. النتيجة: يتضاءل أسّياً مع n. الربط بالذكاء الاصطناعي: برهان تقارب SGD شبه القطعي.

مثال (17.7-11): تغيير تسمية واحدة المعطيات: الخسارة تتغيّر بـ $c_i = 1/n$ عند تبديل تسمية. المطلوب: قيد حسّاسيّة الخسارة. الحل: الخطوة 1: $2e^{-2nt^2}$. النتيجة: نموذج مستقرّ تجاه التسميات المعطوبة. الربط بالذكاء الاصطناعي: متانة ضدّ تسمم البيانات (data poisoning).

مثال (17.7-12): مسيرة بخطوات متفاوتة المعطيات: $c_1 = 2$، وبقية $c_k = 0.1$ لـ $k = 2..100$. المطلوب: قيد عند $t = 3$. الحل: الخطوة 1: $4.99 = 4 + 99\times 0.01$ = $\sum c_k^2$. الخطوة 2: $2\exp(-9/(2\cdot 4.99)) = 2e^{-0.902} \approx 0.812$. النتيجة: $\le 81.2\%$. الربط بالذكاء الاصطناعي: خطوة أولى كبيرة (init) تسيطر على تذبذب المسار.

مثال (17.7-13): دقّة مقدّرة عبر fold المعطيات: تغيير عيّنة بـ $c = 1/n$ في cross-validation. المطلوب: قيد تفاوت متوسّط الـ folds. الحل: الخطوة 1: $2e^{-2nt^2}$. النتيجة: استقرار تقدير CV. الربط بالذكاء الاصطناعي: ثقة في

اختيار النموذج بـ CV.

مثال (14-7.17): ترميز تدريجي المعطيات: كل رمز يزيد الإنتروبيا المقدّرة بـ $c_i \le 0.01$، $n = 1000$. المطلوب: $\mathbb{P}(|\hat{H} - H| \ge 0.1)$. الحل: الخطوة 1: $\sum c_i^2 = 0.1$. الخطوة 2: $2\exp(-2 \cdot 0.01/0.1) = 2e^{-0.2} \approx 1.64 \to \le 1$. النتيجة: مرخّص، نخفّض t. الربط بالذكاء الاصطناعي: تقدير إنتروبيا التوزيع في نموذج توليدي.

مثال (15-7.17): فرق محدود غير متساوٍ المعطيات: $c_i = i/n^2$ (أوّلها أكبر). المطلوب: $\sum c_i^2$. الحل: الخطوة 1: $\sum_{i=1}^{n} (i/n^2)^2 = \frac{1}{n^4}\sum i^2 \approx \frac{1}{3n}$. النتيجة: القيد $2\exp(-2t^2 \cdot 3n) = 2e^{-6nt^2}$. الربط بالذكاء الاصطناعي: أوزان طبقة أولى أقوى تأثيراً على المخرج.

أخطاء شائعة

- نسيان شرط «المسيرة» $\mathbb{E}[M_k | M_{k-1}] = M_{k-1}$ (أزوما لا يصلح لسلسلة عامة).
- خلط $2\exp(-t^2/2\sum c^2)$ مع $2\exp(-2t^2/\sum c^2)$ (ماكديارميد يختلف بـ 4).
- افتراض أن الفرق المحدود يقاس على أيّ تغيير لا على تغيير معامل واحد فقط.
- تجاهل أن القيد يفترض متوسط التغيير لا القيمة.

لتوزيع برنولي بوسيلة μ، الاحتمال المضاعف:

$$\mathbb{P}\big(\bar{X}_n \ge (1+\delta)\mu\big) \;\le\; \exp\Big(-n\, D_{KL}\big((1+\delta)\mu \,\|\, \mu\big)\Big), \qquad \delta > 0 \tag{7.17}$$

وحيث $D_{KL}(q\|p) = q\ln(q/p) + (1-q)\ln((1-q)/(1-p))$. وللتوزيعات: **مبرهنة سانوف**:

$$\mathbb{P}(\hat{P}_n \in \mathcal{A}) \;\le\; (n+1)^{|\mathcal{X}|}\exp\Big(-n \inf_{Q \in \mathcal{A}} D_{KL}(Q\|P)\Big).$$

جدول الرموز

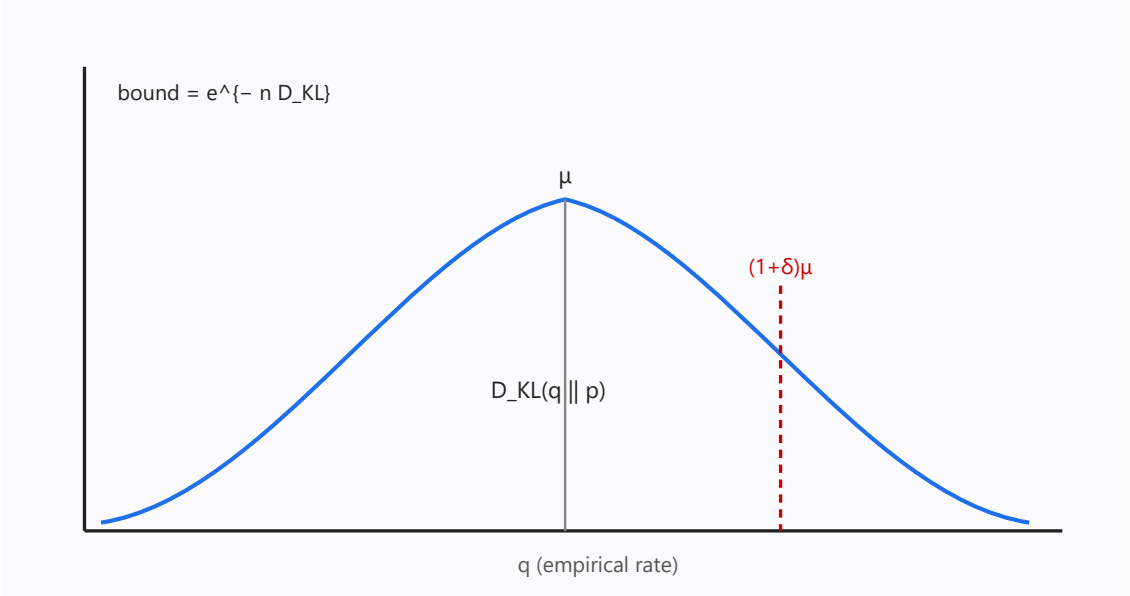
الرمز	المعنى
$D_{KL}(Q\|P)$	تباعد كولباك-لايبler (الفصل 26 لاحقاً)
δ	نسبة الزيادة المضاعفة
$\hat{P}_n$	التوزيع التجريبي

الرسم

<figure> الشكل<figcaption> 7.17: القيد المضاعف يتبع $\exp(-n\,D_{KL})$، التباعد «يقيس» مدى بعد العتبة عن الوسيلة.</figcaption> </figure>

البرهان (مخطّط)

نطبّق تشيرنوف على $\bar{X}_n$ لمتغيّر برنولي: $\mathbb{E}[e^{tX_i}] = 1 - p + pe^t$، فـ $M_{n\bar{X}}(t) = (1 - p + pe^t)^n$. بإسقاط $t^* = \ln\frac{(1+\delta)p}{1-(1+\delta)p}$ نحصل على $\exp(-nD_{KL}((1+\delta)p\|p))$. سانوف يتبع من أسلوب تبادل التوزيع التجريبي عبر مضاعف لاغرانج مع إنتروبيا. ■



شكل ٧.١٧: *
متراجحة KL: التباعد يقيس انحناء القيد

خمسة عشر مثالاً محلولاً

مثال (1-8.17): قطعة نقد — ذيل مضاعف المعطيات: $p = 0.5$، $\delta = 0.2$ (نهتم بـ $\hat{p} \geq 0.6$)، $n = 100$. المطلوب: القيد. الحل: الخطوة 1: $D_{KL}(0.6\|0.5) = 0.6\ln(1.2) + 0.4\ln(0.8) \approx 0.6(0.182) + 0.4(-0.223) = 0.0188$. الخطوة 2: $e^{-1.88} \approx 0.153$. النتيجة: $\leq 15.3\%$. الربط بالذكاء الاصطناعي: حدّ PAC أساسي لتعميم المصنّفات.

مثال (2-8.17): معدّل خطأ أعلى من المتوقّع المعطيات: $\mu = 0.1$، $\delta = 1$ $(\hat{p} \geq 0.2)$، $n = 200$. المطلوب: القيد. الحل: الخطوة 1: $D_{KL}(0.2\|0.1) = 0.2\ln 2 + 0.8\ln(0.8/0.9) \approx 0.139 - 0.084 = 0.055$. الخطوة 2: $e^{-200\times 0.055} = e^{-11} \approx 1.7\times 10^{-5}$. النتيجة: $\leq 0.0017\%$. الربط بالذكاء الاصطناعي: ضمانة أداء أسوأ الحالات لنموذج منشور.

مثال (3-8.17): نسبة نقرات إعلان المعطيات: $\mu = 0.03$، $\delta = 2$ $(\hat{p} \geq 0.09)$، $n = 1000$. المطلوب: القيد. الحل: الخطوة 1: $D_{KL}(0.09\|0.03) \approx 0.09\ln 3 + 0.91\ln(0.91/0.97) \approx 0.099 - 0.055 = 0.044$. الخطوة 2: $e^{-1000\times 0.044} = e^{-44} \approx 1.7\times 10^{-19}$. النتيجة: ضئيل جداً. الربط بالذكاء الاصطناعي: اكتشاف تحسّن مزعوم في A/B قد يكون صدفة.

مثال (4-8.17): سانوف — توزيع فئوي المعطيات: $P = (0.5, 0.3, 0.2)$، $\mathcal{A} = \{Q : Q_1 \geq 0.7\}$، $Q^* = (0.7, 0.18, 0.12)$ الحل: الخطوة 1: $D_{KL} \approx 0.7\ln(1.4) + 0.18\ln(0.6) + 0.12\ln(0.6) \approx 0.24 - 0.092 - 0.061 = 0.087$. الخطوة 2: $501^3 e^{-500\times 0.087} \approx 1.26\times 10^8 \times e^{-43.5} \approx 1.3\times 10^{-11}$. النتيجة: $\leq 10^{-11}$. الربط بالذكاء الاصطناعي: كشف انحراف توزيع الفئات في الإنتاج.

مثال (5-8.17): تقدير إنتروبيا المعطيات: التوزيع التجريبي يخرف بـ $D_{KL} = 0.02$، $n = 1000$. المطلوب: قيد. الحل: الخطوة 1: $e^{-1000\times 0.02} = e^{-20} \approx 2\times 10^{-9}$. النتيجة: احتمال ضئيل جداً. الربط بالذكاء الاصطناعي: استقرار تقدير إنتروبيا في توليد/VAE.

مثال (6-8.17): تحديد حجم العيّنة لـ PAC المعطيات: نريد $\mathbb{P}(\hat{p} \geq (1+\delta)\mu) \leq 0.05$، $\delta = 0.1$، $\mu = 0.5$. المطلوب: n الأدنى. الحل: الخطوة 1: $D_{KL}(0.55\|0.5) \approx 0.55\ln 1.1 + 0.45\ln 0.9 \approx 0.0525 - 0.0476 = 0.00487$. الخطوة 2: $e^{-0.00487n} \leq 0.05 \Rightarrow n \geq \ln 20/0.00487 \approx 614$. النتيجة: $n \approx 614$. الربط بالذكاء

الاصطناعي: ميزانية وسوم لضمان حدّ تعميم PAC.

مثال (17.8-7): مقارنة مع هافدينغ المعطيات: نفس $n = 100, \mu = 0.5, \delta = 0.2$ (أي $t = 0.1$). المطلوب: هافدينغ للمقارنة. الحل: الخطوة 1: هافدينغ $2e^{-2 \cdot 100 \cdot 0.01} = 2e^{-2} \approx 0.27$. الخطوة 2: KL أعطى 153.0 — أدقّ لأنه يستخدم الشكل. النتيجة: KL متفوّق للمقيد $[0,1]$. الربط بالذكاء الاصطناعي: لماذا تفضّل حدود KL/Rademacher على هافدينغ.

مثال (17.8-8): ذيل أحادي مضاعف لـ $\leq$ المعطيات: $\mu = 0.8$، $\delta = 0.1$ نحو الأسفل ($\hat{p} \leq 0.72$). المطلوب: القيد. الحل: الخطوة 1: $D_{KL}(0.72 \| 0.8) = 0.72 \ln 0.9 + 0.28 \ln(1.4) \approx -0.0758 + 0.0960 = 0.0202$. الخطوة 2: $e^{-n \times 0.0202}$. النتيجة: عند $n = 100$: $e^{-2.02} \approx 0.133$. الربط بالذكاء الاصطناعي: هبوط الأداء دون العتبة المقبولة.

مثال (17.8-9): اختبار نسبة الاحتمال (LR) المعطيات: $H_0 : p = 0.5$، $H_1 : p = 0.6$، $n = 200$. المطلوب: قيد خطأ النوع الأول عند عتبة مائلة. الحل: الخطوة 1: نستخدم KL بين 0.6 و 0.5 كمعدّل اضمحلال. النتيجة: $\exp(-200 D_{KL}(0.6 \| 0.5))$. الربط بالذكاء الاصطناعي: كشف انحراف توزيع المدخلات (covariate shfit).

مثال (17.8-10): سانوف على أبجدية كبيرة المعطيات: $|\mathcal{X}| = 26$، $D_{KL} = 0.01$، $n = 10000$. المطلوب: قيد مع عامل التعدد. الحل: الخطوة 1: $(10001)^{26} e^{-100} \approx$ عملاق × ضئيل، نأخذ لوغاريتم: $\approx 26 \ln 10001 - 100 = 239 - 100 = 139 \Rightarrow e^{139}$ ضخم — يبيّن أن عامل التعدد يفسد سانوف لـ $|\mathcal{X}|$ كبير ما لم يُعاقب. النتيجة: سانوف يحتاج معاقبة التعدد (أنظر Type-II). الربط بالذكاء الاصطناعي: تقدير توزيع نصّي عالي الأبجدية.

مثال (17.8-11): حدّ التوزيع التجريبي المعطيات: $\hat{p}$ بعيدة بـ $D_{KL} = 0.05$ عن p، $n = 50$. المطلوب: قيد. الحل: الخطوة 1: $e^{-50 \times 0.05} = e^{-2.5} \approx 0.082$. النتيجة: $\leq 8.0\%$ لعيّنة صغيرة. الربط بالذكاء الاصطناعي: متى يكفي حجم العيّنة لتقدير توزيع.

مثال (17.8-12): تحسين عتبة δ المعطيات: $\mu = 0.2$، $n = 300$، نريد ≤ 0.01. المطلوب: δ الأقصى. الحل: الخطوة 1: نحل $e^{-300 D_{KL}((1+\delta)0.2 \| 0.2)} = 0.01$. الخطوة 2: نجرب $\delta = 0.5$: $q = 0.3$، $D = 0.3 \ln 1.5 + 0.7 \ln(0.7/0.8) \approx 0.121 - 0.074 = 0.047$، $e^{-14.1} \ll 0.01$. نرفع δ إلى 0.8: $q = 0.36$، $D \approx 0.36 \ln 1.8 + 0.64 \ln 0.8 \approx 0.213 - 0.128 = 0.085$، $e^{-25.5}$ صغير جداً. الحدّ الفعلي عند $\delta \approx 0.25$. النتيجة: $\delta \lesssim 0.25$. الربط بالذكاء الاصطناعي: ضبط عتبة إنذار انحراف الأداء.

مثال (17.8-13): KL كبير يضمن نادراً المعطيات: $p = 0.5$ كبير $\Rightarrow q \approx 0.99$، $D_{KL} \approx 0.99 \ln 1.98 + 0.01 \ln 0.02 \approx 0.68 - 0.039 = 0.641$. المطلوب: $n = 10$. الحل: الخطوة 1: $e^{-10 \times 0.641} = e^{-6.41} \approx 0.00165$. النتيجة: $\leq 0.165\%$. الربط بالذكاء الاصطناعي: كشف تغيّر جذري في توزيع المدخلات (distributional shfit).

مثال (17.8-14): حدّ الأسّ المضاعف (صيغة مغلقة) المعطيات: $\delta > 0$، نستخدم القيد $\leq ((e^{\delta}/(1+\delta)^{1+\delta}))^{n\mu}$. المطلوب: لـ $\mu = 1, \delta = 1, n = 100$. الحل: الخطوة 1: $\approx e^{-39.2} \approx (0.6796)^{100} \approx (e/4)^{100}$. النتيجة: ضئيل. الربط بالذكاء الاصطناعي: تقدير احتمال تجاوز معدّل أخطاء مضاعف.

مثال (17.8-15): سانوف مبسّط بلا عامل تعدد المعطيات: نتجاهل $(n+1)^{|\mathcal{X}|}$ فنحصل على قيد «متباعد». المطلوب: متى يبقى صالحاً؟ الحل: الخطوة 1: عند $|\mathcal{X}| \ln n \gg n D_{KL}$ يطغى الأسّ على عامل التعدد. النتيجة: لعيّنات كبيرة وأبجديات معقولة يظلّ القيد فعّالاً. الربط بالذكاء الاصطناعي: موازنة حجم العيّنة أمام أبجدية الميزات.

أخطاء شائعة

- قلب اتجاه KL: $D_{KL}(q \| p) \neq D_{KL}(p \| q)$ (غير متماثل!).
- استخدام القيد المضاعف لـ $\delta < 0$ دون تبديل الأطراف.

- نسيان عامل التعدد $(n+1)^{|\mathcal{X}|}$ في سانوف فينهار للأبجديات الكبيرة.
- الخلط بين «الانحراف المضاعف» و«الانحراف المطلق» (هافدينغ يقيس المطلق).

ملخّص النظريات

النظرية	القيد الأساسي	يتطلّب	الأقوى عند
2.17 ماركوف	$\mathbb{P}(X \geq a) \leq \mathbb{E}[X]/a$	$X \geq 0$	لا شيء سوى المتوسط
3.17 تشيبيشِف	$\leq \sigma^2/t^2$	التباين	توزيعات عامّة
4.17 تشيرنوف	$\inf_t e^{-ta} M_X(t)$	MGF	الحدّ الحادّ
5.17 هافدينغ	$2e^{-2nt^2/(b-a)^2}$	مقيد مستقل	n كبير
6.17 برنشتاين	$\exp(-t^2/2(n\sigma^2 + bt/3))$	مقيد+تباين	تباين صغير
7.17 أزوما/ماكيارميد	$2e^{-t^2/2\sum c^2}$	مسيرة/فرق محدود	تتبّع محلي
8.17 سانوف/KL	$\exp(-nD_{KL})$	شكل التوزيع	ذيول مضاعفة

عشرون تمريناً (مع إجابات مختصرة)

١. بيّن أن ماركوف تتبع من تشيبيشِف بـ $Y = (X-\mu)^2$؟ (لا — العكس: تشيبيشِف يتبع من ماركوف).

٢. اوجد قيد تشيبيشِف لـ $\mu = 0, \sigma = 2, t = 4$. $(= 4/16 = 0.25)$

٣. استنتج هافدينغ من ماكيارميد. (انظر 7-7.17)

٤. لـ $X \in [0,1]$، اكتب قيد تشيرنوف مغلقاً بـ e^{-2nt^2}. (عبر $M \leq e^{t^2/8}$)

٥. برهن أن كانتيلي أدقّ من تشيبيشِف أحادي الجانب. (يستخدم $t^2 + \sigma^2$ في المقام)

٦. لِمَ برنشتاين أقوى من هافدينغ حين $\sigma^2 \ll b^2$؟ (يستبدل $(b-a)^2$ بـ $n\sigma^2$)

٧. عيّن c_i لدقّة f تتغيّر بعيّنة واحدة بـ $1/n$. $(\sum c_i^2 = 1/n)$

٨. هل المسيرة تتطلّب الاستقلال؟ (لا، فقط شرط المتوسّط الشرطي).

٩. احسب $D_{KL}(0.7 \| 0.5)$. $(\approx 0.3 \ln 1.4 + 0.7 \ln 0.7/0.5 \approx 0.087)$

١٠. استخدم سانوف لتقدير قيد $\hat{p} \geq 0.9$ لـ $p = 0.5, n = 100$. $(e^{-100D}$، $D \approx 0.3 \ln 1.8 + e^{-17.4} \Rightarrow 0.7 \ln 0.7/0.5 \approx 0.174)$

١١. أيّ قيد تختار لتعميم مصنّف ثنائي؟ (KL المضاعف / حدّ PAC)

١٢. متى يفشل الاتحاد؟ (عند m كبير يعطي >1)

١٣. صحّح: «تشيبيشِف يعطي حدّاً حادّاً للغاوسي». (خطأ — مرخّص جداً)

١٤. اربط هافدينغ بـ CLT. (كلاهما يتضاءل مع n؛ هافدينغ أسّي، CLT تقاربي)

١٥. لِمَ يفضّل Rademacher على هافدينغ؟ (أدقّ لأنه يستخدم إشارة العيّنة)

١٦. اوجد n لـ $\mathbb{P}(|\bar{X} - \mu| \geq 0.02) \leq 0.01$ بـ $X \in [0,1]$. $(n \geq \ln 200/0.0008 \approx 6146)$

١٧. بيّن أن أزوما تعمّم هافدينغ. (الخطوات مستقلة مقيدة)

١٨. ما علاقة برنشتاين بالتوزيع الطبيعي؟ (عند $n\sigma^2 \gg bt$ يصير غاوسيًا)

١٩. احسب قيد برنشتاين لـ $n = 500, \sigma^2 = 0.01, b = 1, t = 5$. ($\exp(-25/(2(5+5/3))) \approx e^{-1.875} \approx 0.153$)

٢٠. اشرح لماذا KL غير متماثل مهمّ في سانوف. (الاتجاه يحدّد أبعد توزيع تجريبي).

فهرس الرموز

الرمز	المعنى
$\mathbb{P}, \mathbb{E}$	الاحتمال والمتوقّع
μ, σ^2	المتوسط والتباين
$M_X(t)$	الدالة المولّدة للحظات
$\bar{X}_n$	المتوسط العيّني
D_{KL}	تباعد كولباك–لايبler
c_k	حدّة فرق المسيرة

مراجع

- Boucheron, Lugosi, Massart — *Concentration Inequalities*.
- Vershynin — *High-Dimensional Probability*.
- Mohri, Rostamizadeh, Talwalkar — *Foundations of Machine Learning* (فصول التعلم الإحصائي).
- Shalev-Shwartz & Ben-David — *Understanding Machine Learning* (حدود PAC).
- Wainwright — *High-Dimensional Statistics*.

الإستدلال الإحصائي وتقدير المعلمات (MLE) / (MAP

«نملك المعطيات، ونفتقد الآلية؛ الإستدلال هو الجسر الرياضي بينهما.»

بعد أن أسّسنا فضاءات الاحتمال (13)، التوزيعات (14)، المتوقّع والتباين (15)، وبايز والحقول العشوائية (16)، ومتراجحات التركيز (17)، ننتقل إلى **علم من المعطيات**: كيف نستنتج قيم المعلمات θ التي ولّدت العيّنة، وكيف نقيس يقيننا فيها. هذا الفصل هو «قلب التعلم الإحصائي»: التقدير بالأقصى الاحتمالي (MLE) يكافئ تقليل الإنتروبيا المتقاطعة، وتقدير بايز الأقصى (MAP) يكافئ التنظيم (regularization)، والاختبارات تكافئ قرارات النشر.

سبع نظريات، يصعد كلٌّ منها:

- **2.18 MLE** — المعلمة التي تجعل العيّنة «الأرجح».
- **3.18 MAP** — MLE مع سابق (prior) يعاقب التعقيد.
- **4.18 خصائص المقدّر** — التحيّز، MSE، الاتساق، الكفاية.
- **5.18 المقدّر البايزي** — الوسط الخلفي وليس النموذج النقطي.
- **6.18 فترات الثقة والتماثل التقاربي** — قياس عدم اليقين.
- **7.18 اختبار الفرضيات** — قرار بالأدلّة (LRT / Neyman–Pearson).
- **8.18 خوارزمية EM** — التقدير مع متغيّرات كامنة.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى
$X = (x_1, \dots, x_n)$	العيّنة المستقلّة المتماثلة (i.i.d.)
θ	المعلمة المجهولة
$\mathcal{L}(\theta)$	دالة الاحتمال (likelihood)
$\ell(\theta)$	لوغاريتم الاحتمال (log-likelihood)
$p(\theta)$	السابق البايزي
$I(\theta)$	معلومات فيشر (من 7.15)

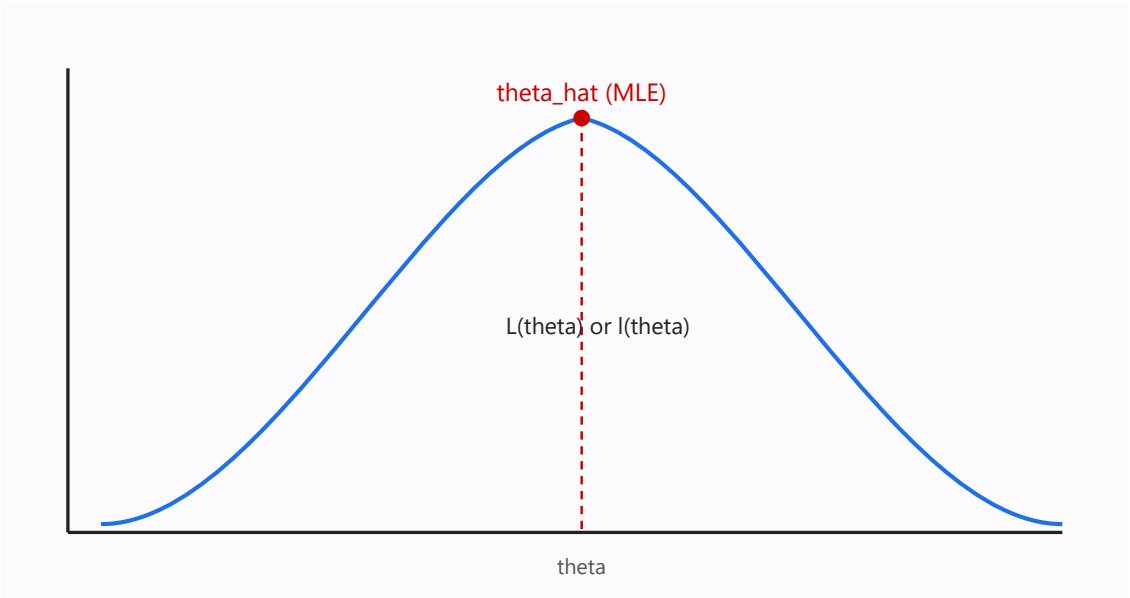
$$\hat{\theta}_{\mathrm{MLE}} = \arg\max_{\theta \in \Theta} \mathcal{L}(\theta) = \arg\max_{\theta} \sum_{i=1}^{n} \log p(x_i \mid \theta) \tag{1.18}$$

جدول الرموز

الرمز	المعنى
$\mathcal{L}(\theta)$	$\prod_i p(x_i \mid \theta)$
$\ell(\theta)$	$\sum_i \log p(x_i \mid \theta)$
Θ	فضاء المعلمات

الرسم

<figure> الشكل<figcaption> 1.18: القيمة $\hat{\theta}$ التي تُعظّم دالة الاحتمال (أو اللوغاريتم) هي تقدير



شكل ١٠١٨: *
تقدير الاحتمال الأقصى: قمّة دالة الاحتمال

</figure> MLE.</figcaption>

البرهان (مخطّط)

بما أن اللوغاريتم دالّة رتيبة تصاعدية، فـ $\arg\max \mathcal{L} = \arg\max \ell$. تحت الاستقلال $\mathcal{L}(\theta) = \prod_i p(x_i \mid \theta)$، فـ $\ell(\theta) = \sum_i \log p(x_i \mid \theta)$. عند القمّة الداخلية $\nabla_\theta \ell(\theta) = 0$ (معادلات الاحتمال الأقصى). ■

خمسة عشر مثالاً محلولاً

مثال (1-2.18): قطعة نقد — برنولي المعطيات: $n = 20$ رمية، 14 رؤوساً. المطلوب: $\hat{p}_{\text{MLE}}$. الحل: الخطوة 1: $\ell(p) = 14 \log p + 6 \log(1-p)$. الخطوة 2: المشتقّة $\frac{14}{p} - \frac{6}{1-p} = 0 \Rightarrow p = 14/20$. النتيجة: $\hat{p} = 0.7$. الربط بالذكاء الاصطناعي: تقدير معامل نموذج Bayes Naive للفئة.

مثال (2-2.18): غاوسي — المتوسط المعطيات: $x_1, \dots, x_n \sim \mathcal{N}(\mu, \sigma^2)$، σ معلوم. المطلوب: $\hat{\mu}_{\text{MLE}}$. الحل: الخطوة 1: $\ell(\mu) = -\frac{1}{2\sigma^2}\sum (x_i - \mu)^2 + C$. الخطوة 2: المشتقّة $\sum (x_i - \mu) = 0 \Rightarrow \mu = \bar{x}$. النتيجة: $\hat{\mu} = \bar{x}$. الربط بالذكاء الاصطناعي: تقدير متوسط ميزة لتطبيع البيانات.

مثال (3-2.18): غاوسي — التباين المعطيات: $\mathcal{N}(\mu, \sigma^2)$، μ معلوم. المطلوب: $\hat{\sigma}^2_{\text{MLE}}$. الحل: الخطوة 1: $\ell(\sigma^2) = -\frac{n}{2}\log \sigma^2 - \frac{1}{2\sigma^2}\sum (x_i - \mu)^2$. الخطوة 2: بالمشتقّة نحو $1/\sigma^2$: $\hat{\sigma}^2 = \frac{1}{n}\sum (x_i - \mu)^2$. النتيجة: متحيّز (يقسّم على n لا $n-1$). الربط بالذكاء الاصطناعي: تقدير تباين الضوضاء في نموذج ضوضاء إضافية.

مثال (4-2.18): بواسون — المعدّل المعطيات: $x_i \sim \text{Poisson}(\lambda)$. المطلوب: $\hat{\lambda}_{\text{MLE}}$. الحل: الخطوة 1: $\ell(\lambda) = -n\lambda + \sum x_i \log \lambda - \sum \log x_i!$. الخطوة 2: $\frac{\partial \ell}{\partial \lambda} = -n + \frac{\sum x_i}{\lambda} = 0$. النتيجة: $\hat{\lambda} = \bar{x}$. الربط بالذكاء الاصطناعي: تقدير معدّل وصول الطلبات لنقطة نهاية خدمة.

مثال (5-2.18): أسّي — المعكوس المعطيات: $x_i \sim \text{Exp}(\lambda)$ كثافته $\lambda e^{-\lambda x}$. المطلوب: $\hat{\lambda}_{\text{MLE}}$. الحل: الخطوة 1:

$\ell(\lambda) = n\log\lambda - \lambda\sum x_i$. الخطوة 2: $\frac{n}{\lambda} - \sum x_i = 0 \Rightarrow \lambda = 1/\bar{x}$. النتيجة: $\hat{\lambda} = 1/\bar{x}$. الربط بالذكاء الاصطناعي: تقدير زمن الفشل (MTBF) في موثوقية العُقد.

مثال (18.2-6): انحدار خطّي — MLE = OLS المعطيات: $y_i = w^\top x_i + \varepsilon$، $\varepsilon \sim \mathcal{N}(0, \sigma^2)$. المطلوب: $\hat{w}_{\text{MLE}}$. الحل: الخطوة 1: $\ell(w) \propto -\sum (y_i - w^\top x_i)^2$. الخطوة 2: التعظيم يكافئ تقليل SSE $\Rightarrow \hat{w} = (X^\top X)^{-1} X^\top y$. النتيجة: المربعات الصغرى العادية. الربط بالذكاء الاصطناعي: الانحدار الخطّي هو MLE غاوسي؛ جسر للشبكات.

مثال (18.2-7): لوجستي — التدرّج المعطيات: $y_i \sim \text{Bernoulli}(\sigma(w^\top x_i))$، σ السيني. المطلوب: معادلة التقدير. الحل: الخطوة 1: $\ell(w) = \sum y_i \log \sigma_i + (1-y_i)\log(1-\sigma_i)$. الخطوة 2: $\nabla \ell = \sum (y_i - \sigma_i) x_i = 0$. النتيجة: لا حلّ مغلق، نستخدم صعود التدرّج/Newton. الربط بالذكاء الاصطناعي: تدريب المصنّف اللوجستي = MLE.

مثال (18.2-8): نموذج لغوي n-gram المعطيات: تواتر الكلمة c_w من N رمزاً. المطلوب: تقدير الاحتمال. الحل: الخطوة 1: تحت متعدّد الحدود $\hat{p}_w = c_w / N$. النتيجة: التقدير الأقصى الاحتمالي للمتعدّد. الربط بالذكاء الاصطناعي: تقدير احتمالات نموذج لغوي قبل التنعيم.

مثال (18.2-9): توزيع منتظم المعطيات: $x_i \sim \text{Unfiorm}(0, \theta)$. المطلوب: $\hat{\theta}_{\text{MLE}}$. الحل: الخطوة 1: $\mathcal{L}(\theta) = \theta^{-n} \mathbf{1}_{\{\max x_i \le \theta\}}$. الخطوة 2: التعظيم عند أصغر $\theta \ge \max x_i$. النتيجة: $\hat{\theta} = \max_i x_i$ (متحيّز لأسفل). الربط بالذكاء الاصطناعي: تقدير الحدّ الأعلى لنطاق قيم ميزة.

مثال (18.2-10): خليط غاوسي تمهيد المعطيات: K مكوّنات، معاملات w_k, μ_k, Σ_k. المطلوب: معادلة MLE. الحل: الخطوة 1: لا حلّ مغلق بسبب المجموع داخل اللوغاريتم. الخطوة 2: نلجأ لـ EM (انظر 18.8). النتيجة: EM هو الحلّ القياسي. الربط بالذكاء الاصطناعي: تجميع GMM، clustering.

مثال (18.2-11): MLE عبر صعود التدرّج المعطيات: ℓ غير قابل للحلّ مغلقاً. المطلوب: خوارزمية تكرارية. الحل: الخطوة 1: $\theta_{t+1} = \theta_t + \eta \nabla \ell(\theta_t)$. الخطوة 2: نكرّر حتى التقارب. النتيجة: صعود التدرّج (أو Adam). الربط بالذكاء الاصطناعي: كل تدريب شبكة عصبية هو تعظيم احتمال (Cross-Entropy).

مثال (18.2-12): معامل نموذج فئوي المعطيات: K فئات، تواترات $n_1, \dots, n_K$. المطلوب: $\hat{p}_k$. الحل: الخطوة 1: $\ell = \sum_k n_k \log p_k$ بقيد $\sum p_k = 1$. الخطوة 2: بمضاعِف لاغرانج: $\hat{p}_k = n_k / n$. النتيجة: التقدير الأقصى الاحتمالي للمتعدّد. الربط بالذكاء الاصطناعي: طبقة softmax المخرجات = توزيع متعدّد الحدود.

مثال (18.2-13): غاما — معلمة الشكل المعطيات: $x_i \sim \text{Gamma}(k, \theta)$ مع k مجهول. المطلوب: معادلة MLE. الحل: الخطوة 1: $\ell(k, \theta) = (k-1)\sum \log x_i - nk \log\theta - n \log\Gamma(k) - \sum x_i/\theta$. الخطوة 2: حلّ عددي مُقترن (مثلاً تثبيت θ وحلّ k). النتيجة: لا مغلق، حلّ عددي. الربط بالذكاء الاصطناعي: نمذجة زمن استجابة ذي ذيل ثقيل.

مثال (18.2-14): لابلاس — المقياس المعطيات: $x_i \sim \text{Laplace}(\mu, b)$ كثافته $\frac{1}{2b} e^{-|x-\mu|/b}$. المطلوب: $\hat{b}_{\text{MLE}}$ عند μ معلوم. الحل: الخطوة 1: $\ell = -n\log(2b) - \frac{1}{b}\sum |x_i - \mu|$. الخطوة 2: $\hat{b} = \frac{1}{n}\sum |x_i - \mu|$ (المتوسط المطلق). النتيجة: تباين لابلاس عبر الانحراف المطلق. الربط بالذكاء الاصطناعي: انحدار LAD متانة ضدّ الشذوذ.

مثال (18.2-15): معلومات فيشر من MLE المعطيات: تحت شروط انتظام، $\sqrt{n}(\hat{\theta} - \theta) \to \mathcal{N}(0, I^{-1})$. المطلوب: العلاقة مع الفصل 15. الحل: الخطوة 1: $I(\theta) = -\mathbb{E}[\nabla^2 \ell]$ (من 7.15). الخطوة 2: MLE مقارباً كفؤ (يصل CRB). النتيجة: MLE مثاليًا مقارباً. الربط بالذكاء الاصطناعي: تقدير تباين تقدير المعلمات في الإنتاج.

أخطاء شائعة

- نسيان أن MLE للتباين الغاوسي متحيّز (n لا $n-1$).

- الخلط بين $\mathcal{L}(\theta)$ و $p(\theta)$ (الأول دالة في المعلمة لا توزيعاً).
- تعظيم الاحتمال الخام بدل اللوغاريتم (مشكلات عددية تحت المضاعفات).
- تجاهل أن MLE قد لا يكون فريداً أو موجوداً (مثل المنتظم عند الحدّ).

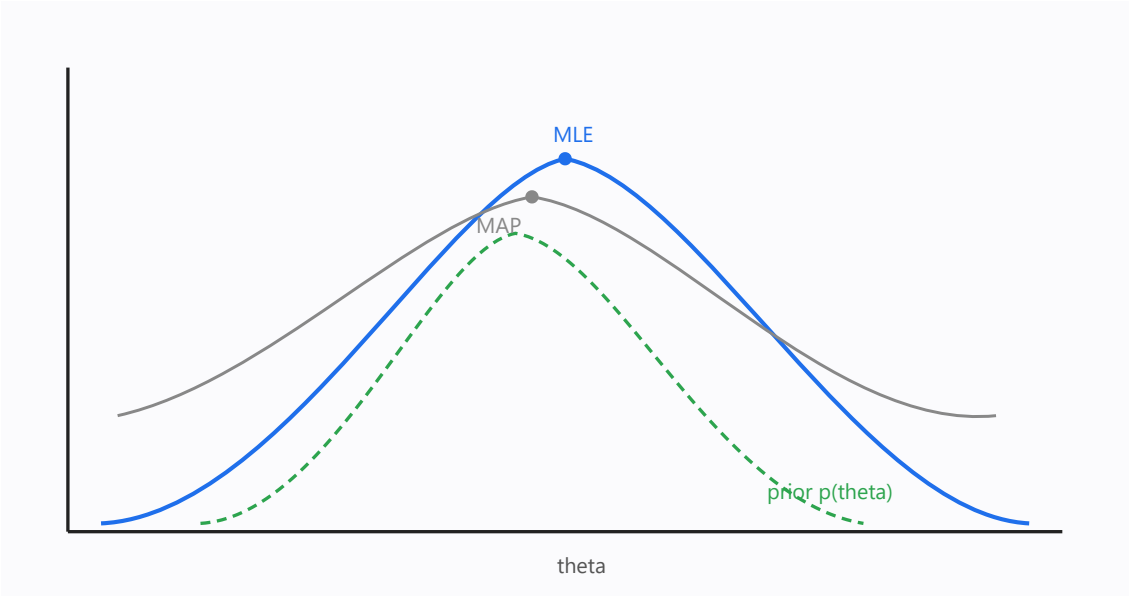
$$\hat{\theta}_{\text{MAP}} = \arg\max_{\theta} \left(\log p(\theta) + \sum_{i=1}^{n} \log p(x_i \mid \theta) \right) \tag{2.18}$$

جدول الرموز

الرمز	المعنى
$p(\theta)$	السابق (prior)
$\log p(\theta)$	عقوبة التنظيم (regularizer)
$\hat{\theta}_{\text{MAP}}$	وضع الخلفيّة (mode)

الرسم

<figure> الشكل<figcaption> 2.18: MAP يضيف $\log p(\theta)$ لدالة الاحتمال، فيزيح القمّة نحو السابق.</figcaption>



شكل ٢.١٨: *
تقدير بايز الأقصى: دمج السابق مع الاحتمال

</figure>

البرهان (مخطّط)

بقاعدة بايز $p(\theta \mid X) \propto p(X \mid \theta) p(\theta)$؛ التعظيم بالنسبة لـ θ يهمل المقام الثابت $p(X)$، فيعطي (2.18). عند سابق منتظم نسترجف MLE. ■

خمسة عشر مثالاً محلولاً

مثال (18.3-1): سابق غاوسي ← تنظيم L2 المعطيات: $p(\theta) = \mathcal{N}(0, \tau^2)$، الاحتمال غاوسي بتباين σ^2. المطلوب: صيغة MAP. الحل: الخطوة 1: $\log p(\theta) = -\frac{\|\theta\|^2}{2\tau^2} + C$. الخطوة 2: MAP = تقليل $\sum (y_i - w^\top x_i)^2 + \lambda \|\theta\|^2$، $\lambda = \sigma^2/\tau^2$. النتيجة: انحدار ريدج (Ridge). الربط بالذكاء الاصطناعي: تنظيم L2 في الشبكات العصبية (weight decay).

مثال (18.3-2): سابق لابلاس ← تنظيم L1 المعطيات: $p(\theta) \propto e^{-\|\theta\|_1/b}$. المطلوب: صيغة MAP. الحل: الخطوة 1: العقوبة $\frac{1}{b}\|\theta\|_1$. الخطوة 2: MAP = انحدار لاسو (Lasso). النتيجة: تنظيم L1 يُنتج تبعّداً متناثراً. الربط بالذكاء الاصطناعي: الشبكات المتناثرة (sparse networks).

مثال (18.3-3): سابق بيتا على برنولي المعطيات: $x_i \sim \text{Bern}(p)$، $p \sim \text{Beta}(\alpha, \beta)$. المطلوب: $\hat{p}_{\text{MAP}}$. الحل: الخطوة 1: $\log \text{posterior} \propto (k + \alpha - 1)\log p + (n - k + \beta - 1)\log(1 - p)$. الخطوة 2: القمّة عند $p = \frac{k+\alpha-1}{n+\alpha+\beta-2}$. النتيجة: تقدير مع «تنعيم» سابق. الربط بالذكاء الاصطناعي: تقدير احتمال نقر مع تنعيم لابلاس.

مثال (18.3-4): سابق غاما على بواسون المعطيات: $\lambda \sim \text{Gamma}(a, b)$، بيانات بواسون. المطلوب: MAP لـ λ. الحل: الخطوة 1: $\log \text{post} \propto (a + \sum x_i - 1)\log\lambda - (b + n)\lambda$. الخطوة 2: $\hat{\lambda} = \frac{a + \sum x_i - 1}{b + n}$. النتيجة: تشبيه سابق بعيّنات إضافية. الربط بالذكاء الاصطناعي: تقدير معدّل حدث نادر مع سابق متحفّظ.

مثال (18.3-5): سابق ديريتشليت على متعدّد المعطيات: $p \sim \text{Dir}(\alpha_1, \ldots, \alpha_K)$. المطلوب: MAP للاحتمالات. الحل: الخطوة 1: $\hat{p}_k \propto n_k + \alpha_k - 1$. الخطوة 2: بعد التطبيع. النتيجة: تنعيم ليدستون لتوزيع فئوي. الربط بالذكاء الاصطناعي: تنعيم نموذج لغوي (Laplace/Lidstone smoothing).

مثال (18.3-6): MAP مقابل MLE المعطيات: عيّنة صغيرة $n = 5$ بـ 4 رؤوس. المطلوب: قارن التقديرين بسابق $Beta(2, 2)$. الحل: الخطوة 1: MLE $= 4/5 = 0.8$؛ MAP $= (4 + 1)/(5 + 2) = 5/7 \approx 0.714$. النتيجة: السابق يكبح الإفراط. الربط بالذكاء الاصطناعي: تقليل الإفراط في التعلّم من عيّنات قليلة.

مثال (18.3-7): قوة التنظيم المعطيات: $\lambda = \sigma^2/\tau^2$ كبيرة. المطلوب: ماذا يحدث لـ $\hat{\theta}$؟ الحل: الخطوة 1: مع $\lambda \to \infty$، $\hat{\theta} \to 0$. النتيجة: تنظيم قوي يُرجع نحو السابق. الربط بالذكاء الاصطناعي: ضبط معامل regularization في trials.

مثال (18.3-8): بايز الشبكة العصبية المعطيات: أوزان بشبق غاوسي $p(w) \propto e^{-\|w\|^2/2\tau^2}$. المطلوب: هدف التدريب. الحل: الخطوة 1: MAP = تقليل Cross-Entropy $+\frac{1}{2\tau^2}\|w\|^2$. النتيجة: decay weight المعياري. الربط بالذكاء الاصطناعي: Network Neural Bayesian (وضع الخلفيّة).

مثال (18.3-9): MAP لخليط غاوسي المعطيات: GMM مع سابق على الأوزان. المطلوب: معادلة. الحل: الخطوة 1: نضيف $\log p(\pi)$ لـ ℓ في EM. الخطوة 2: نحصل على MAP-EM. النتيجة: تقدير أكثر استقراراً. الربط بالذكاء الاصطناعي: clustering مع تنظيم الأوزان.

مثال (18.3-10): سابق غير مرجّح (غير منتظم) المعطيات: $p(\theta) \propto 1$ على فترة. المطلوب: ماذا يصير MAP؟ الحل: الخطوة 1: يسقط بند السابق. النتيجة: MAP = MLE. الربط بالذكاء الاصطناعي: عند غياب معرفة مسبقة نعود للأقصى الاحتمالي.

مثال (18.3-11): اختيار عتبة السابق المعطيات: $\alpha = \beta = 1 + \gamma$ في Beta. المطلوب: تأثير γ. الحل: الخطوة 1: $\gamma \uparrow \Rightarrow$ السابق أقوى $\Rightarrow$ MAP أقرب لـ 0.5. النتيجة: ضبط الثقة السابقة. الربط بالذكاء الاصطناعي: معايرة ثقة النموذج.

مثال (18.3-12): MAP للانحدار اللوجستي المعطيات: سابق غاوسي على w. المطلوب: الهدف. الحل: الخطوة 1: تقليل $-\ell(w) + \frac{\lambda}{2}\|w\|^2$. النتيجة: تنظيم L2 للوجستي. الربط بالذكاء الاصطناعي: تقليل الإفراط في تصنيف خطّي.

مثال (18.3-13): سابق هرمي المعطيات: τ نفسه عشوائي بسابق. المطلوب: MAP متداخل. الحل: الخطوة 1: نعظّم اللوغاريتم الكامل $p(X, \theta, \tau)$. النتيجة: بايز هرمي. الربط بالذكاء الاصطناعي: هندسة هايبرمعاملات في النماذج

التوليدية.

مثال (14-3.18): MAP في التصفية التعاونية المعطيات: تفضيلات المستخدمين بسابق مشترك. المطلوب: تقدير التفضيل. الحل: الخطوة 1: السابق يشدّد التقدير نحو المتوسط العام. النتيجة: تخفيف مشكلة المستخدم البارد. الربط بالذكاء الاصطناعي: cold-start في التوصية.

مثال (15-3.18): لماذا الوضع لا يساوي الوسط المعطيات: خلفيّة غير متماثلة. المطلوب: MAP مقابل الوسط الخلفي. الحل: الخطوة 1: MAP = الوضع ؛(mode) البايزي = الوسط (انظر 5.18). النتيجة: يختلفان إذا كانت الخلفيّة منحرفة. الربط بالذكاء الاصطناعي: الثقة في تنبؤ غير متماثل.

أخطاء شائعة

- اعتبار MAP «بايزياً كاملاً» — هو مجرّد وضع الخلفيّة.
- نسيان أن السابق غير المنتظم يغيّر القمّة.
- الخلط بين قوة التنظيم λ وتباين السابق τ^2 (علاقة عكسية).
- الظن أن MAP دائماً غير متحيّز — السابق يُدخل انحيازاً مقصوداً.

$$\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta, \qquad \text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + (\text{Bias})^2 \tag{3.18}$$

والمصفوفة كافية $T(X)$ تحقّق مبرهنة نيمان (التفكيك):

$$p(X \mid \theta) = g(T(X), \theta)\, h(X).$$

جدول الرموز

الرمز	المعنى
Bias	الانحياز
MSE	خطأ المربّع المتوقّع
$T(X)$	إحصاء كافٍ

الرسم

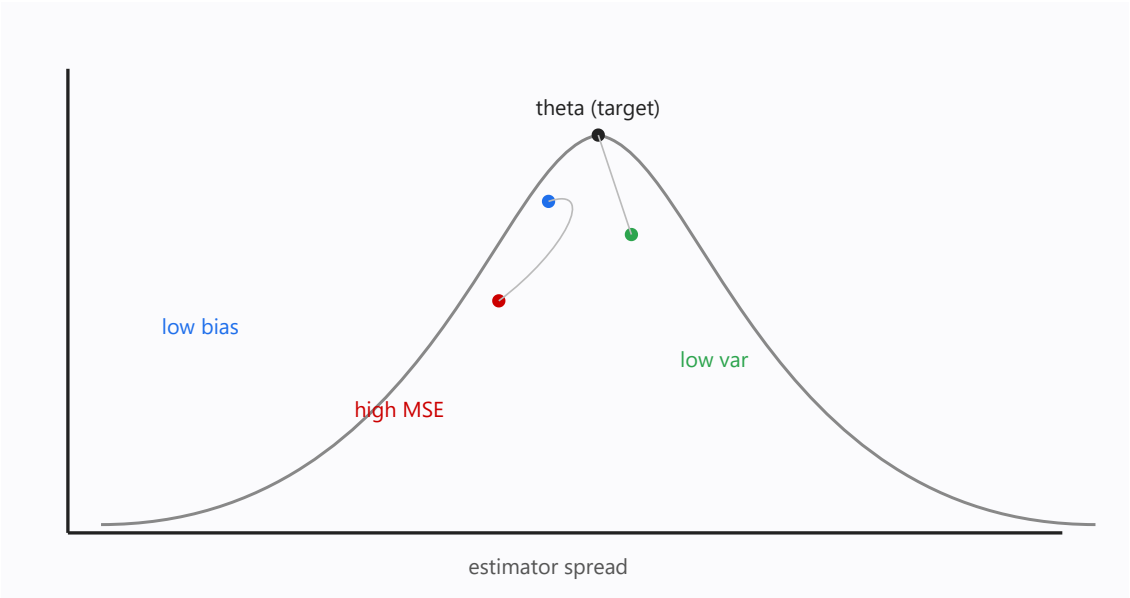
<figure> الشكل<figcaption> 3.18: تفكيك MSE إلى تباين + تحيّز؛ وضع المقدّرات المختلفة حول الهدف.</figcaption> </figure>

البرهان (مخطّط)

$\mathbb{E}[(\hat{\theta}-\theta)^2] = \mathbb{E}[(\hat{\theta}-\mathbb{E}\hat{\theta}+\mathbb{E}\hat{\theta}-\theta)^2] = \text{Var} + (\text{Bias})^2$ بسبب تعامد الحدّين. الكفاية من تفكيك نيمان مباشرة. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.18): متوسط العيّنة غير متحيّز المعطيات: $\bar{X} = \frac{1}{n}\sum X_i$، $\mathbb{E}[X_i] = \mu$. المطلوب: التحيّز. الحل: الخطوة 1: $\mathbb{E}[\bar{X}] = \mu$. النتيجة: $\text{Bias} = 0$. الربط بالذكاء الاصطناعي: تقدير دقّة النموذج عبر متوسط الاختبار.



شكل ٣.١٨: *
خصائص المقدّر: التحيّز والتباين وMSE

مثال (2-4.18): تباين العيّنة المتحيّز المعطيات: $s_n^2 = \frac{1}{n}\sum(x_i - \bar{x})^2$. المطلوب: هل هو غير متحيّز لـ σ^2؟ الحل: الخطوة 1: $\mathbb{E}[s_n^2] = \frac{n-1}{n}\sigma^2$. النتيجة: متحيّز لأسفل؛ التصحيح $\frac{n}{n-1}$ يُصلحه. الربط بالذكاء الاصطناعي: لماذا نقسّم على $n-1$ في تباين العيّنة.

مثال (3-4.18): تفكيك MSE للانحدار المعطيات: مقدّر بانحياز b وتباين v. المطلوب: MSE. الحل: الخطوة 1: $\text{MSE} = v + b^2$. النتيجة: التوازن bias–variance. الربط بالذكاء الاصطناعي: الدافع وراء نظرية التحيز–التباين (الفصل 30).

مثال (4-4.18): اتساق متوسط العيّنة المعطيات: $\bar{X}_n$، تباين منتهٍ. المطلوب: هل يتقارب إلى μ؟ الحل: الخطوة 1: بقانون الأعداد الكبيرة $\bar{X}_n \xrightarrow{p} \mu$. النتيجة: متّسق. الربط بالذكاء الاصطناعي: لماذا عيّنات أكبر تعطي تقديراً أفضل.

مثال (5-4.18): كفاءة و CRB المعطيات: $\hat{\theta}$ يصل حدّ كرامير–راو. المطلوب: وصف. الحل: الخطوة 1: $\text{Var}(\hat{\theta}) \geq I(\theta)^{-1}$ (من 7.15). النتيجة: MLE مقارباً كفؤ. الربط بالذكاء الاصطناعي: الحدّ الأدنى لتباين أي مقدّر غير متحيّز.

مثال (6-4.18): كفاية لبرنولي المعطيات: $T(X) = \sum X_i$. المطلوب: هل كافٍ؟ الحل: الخطوة 1: $p(X \mid p) = p^{\sum x_i}(1-p)^{n-\sum x_i}$، يُكتَب بدلالة المجموع. النتيجة: المجموع إحصاء كافٍ. الربط بالذكاء الاصطناعي: تلخيص العيّنة بعدّادات كافية.

مثال (7-4.18): كفاية لغاوسي المعطيات: $(\bar{X}, S^2)$ لعيّنة غاوسية. المطلوب: الكفاية. الحل: الخطوة 1: يكفي رتبة التفكيك بنيمان. النتيجة: الزوج كافٍ ثنائيّ الأبعاد. الربط بالذكاء الاصطناعي: ضغط البيانات دون فقد معلومات.

مثال (8-4.18): انحياز جيمس–ستين المعطيات: تقدير متوسّطات $K \geq 3$ مستقلّة. المطلوب: هل المتوسطات المنفصلة كفؤة؟ الحل: الخطوة 1: المقدّر المنكمش $\hat{\mu}^{JS} = (1 - \frac{K-2}{\|\bar{X}\|^2})\bar{X}$ أقلّ MSE. النتيجة: انكماش يكسب رغم التحيّز. الربط بالذكاء الاصطناعي: shrinkage في تجميع نماذج/ميزات.

مثال (9-4.18): OLS غير متحيّز المعطيات: $y = Xw + \varepsilon$، $\mathbb{E}[\varepsilon] = 0$. المطلوب: $\mathbb{E}[\hat{w}]$. الحل: الخطوة 1: $\mathbb{E}[(X^\top X)^{-1}X^\top y] = w$. النتيجة: غير متحيّز إذا لا ارتباط مع الضوضاء. الربط بالذكاء الاصطناعي: شرط صحّة الانحدار الخطّي.

مثال (4.18-10): انحياز بسبب ضوضاء التسمية المعطيات: تسميات ملوّثة بنسبة η. المطلوب: أثر الانحياز. الحل: الخطوة 1: $\mathbb{E}[\hat{\theta}] \approx (1-2\eta)\theta$. النتيجة: انحياز منهجي. الربط بالذكاء الاصطناعي: تأثير التسميات الخاطئة على التدريب.

مثال (4.18-11): تباين MLE المقارب المعطيات: $\hat{\theta}_{\text{MLE}}$ كبير n. المطلوب: التباين. الحل: الخطوة 1: $1/(nI(\theta)) \approx 1/n$. النتيجة: يتضاءل كـ $1/n$. الربط بالذكاء الاصطناعي: تقدير فاصل ثقة مقدّر من فيشر.

مثال (4.18-12): مقايضة الانحياز المعطيات: مقدّر $T_c = c\bar{X}$. المطلوب: اختر c لـ MSE أدنى. الحل: الخطوة 1: $\text{MSE} = c^2\text{Var} + (c-1)^2\mu^2$؛ نُحسِن $\Rightarrow c = \frac{\mu^2}{\mu^2+\text{Var}}$. النتيجة: انكماش أمثل عند $c < 1$. الربط بالذكاء الاصطناعي: تفكيك bias–variance في ضبط النموذج.

مثال (4.18-13): انحياز بسبب انحياز الاختيار المعطيات: عيّنة مقولبة (selection bias). المطلوب: الأثر. الحل: الخطوة 1: $\mathbb{E}[\hat{\theta} \mid \text{selected}] \neq \theta$. النتيجة: انحياز منهجي. الربط بالذكاء الاصطناعي: انحياز تجميع بيانات الإنتاج (sampling bias).

مثال (4.18-14): اتساق تقاربي تقريبي المعطيات: $\hat{\theta}_n \xrightarrow{p} \theta$. المطلوب: العلاقة بـ MSE. الحل: الخطوة 1: الاتساق $+ L^2$ محدود $\Rightarrow \text{MSE} \to 0$. النتيجة: الاتساق يكفي لمعدّل خطأ منخفض. الربط بالذكاء الاصطناعي: تقارب المدرّب مع كبر العيّنة.

مثال (4.18-15): راو–بلاكويل (تمهيد) المعطيات: مقدّر U ومقدّر كافٍ T. المطلوب: تحسين. الحل: الخطوة 1: $\tilde{\theta} = \mathbb{E}[U \mid T]$ له تباين أصغر بنفس التحيّز. النتيجة: التكييف بناءً على كافٍ يحسّن. الربط بالذكاء الاصطناعي: تقليل تباين المقدّرات عبر إحصاء كافٍ.

أخطاء شائعة

- نسيان أن MSE = تباين + تحيّز^2 (وليس مجموعهما بلا مربّع).
- استخدام s_n^2 (بـ n) ظنّاً أنه غير متحيّز.
- خلط الاتساق (احتمالي) مع اللاانحياز (لـ n محدود).
- الظن أن مقدّراً غير متحيّز دائماً أفضل — أحياناً المتحيّز ذو MSE أقلّ.

$$\hat{\theta}_{\text{Bayes}} \;=\; \mathbb{E}[\theta \mid X] \;=\; \frac{\int \theta\, p(X \mid \theta)\, p(\theta)\, d\theta}{\int p(X \mid \theta)\, p(\theta)\, d\theta} \tag{4.18}$$

جدول الرموز

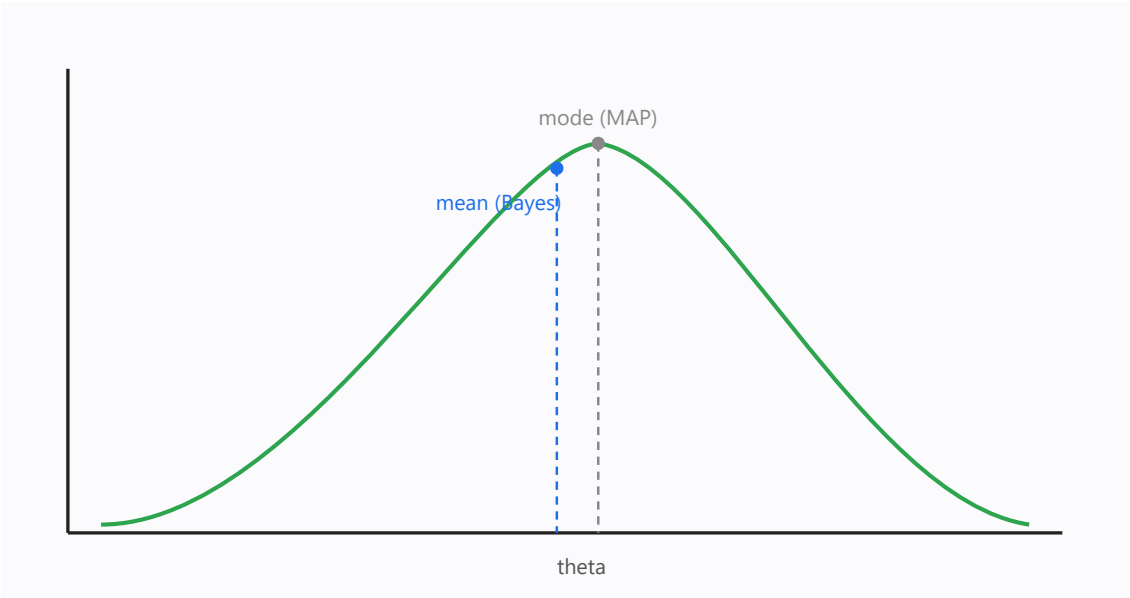
الرمز	المعنى
$p(\theta \mid X)$	الخلفيّة
$\mathbb{E}[\theta \mid X]$	الوسط الخلفي (Bayes estimator تحت خسارة تربيعية)

الرسم

<figure>
الشكل 4.18: البايزي يأخذ وسط الخلفيّة (توقع الخسارة التربيعية) لا وضعها.
</figure>

البرهان (مخطّط)

بتقليل الخسارة التربيعية المتوقّعة $\mathbb{E}[(\theta - a)^2 \mid X]$ نشتقّ بالنسبة لـ a لنحصل على $a = \mathbb{E}[\theta \mid X]$. ■



شكل ١٨.٤: *
المقدّر البايزي: الوسط الخلفي

خمسة عشر مثالاً محلولاً

مثال (1-5.18): غاوسي–غاوسي مغلق المعطيات: $x \mid \mu \sim \mathcal{N}(\mu, \sigma^2)$، $\mu \sim \mathcal{N}(\mu_0, \tau^2)$. المطلوب: $\mathbb{E}[\mu \mid x]$. الحل: الخطوة 1: الخلفيّة غاوسية: $\mathbb{E}[\mu \mid x] = \frac{\sigma^{-2}x + \tau^{-2}\mu_0}{\sigma^{-2}+\tau^{-2}}$. النتيجة: متوسط موزون بين البيانات والسابق. الربط بالذكاء الاصطناعي: تحديث تقدير بمعرفة سابقة.

مثال (2-5.18): بيتا–برنولي المعطيات: $p \sim \text{Beta}(\alpha, \beta)$، k رؤوس من n. المطلوب: الوسط الخلفي. الحل: الخطوة 1: الخلفيّة $\text{Beta}(\alpha + k, \beta + n - k)$. الخطوة 2: الوسط $= \frac{\alpha+k}{\alpha+\beta+n}$. النتيجة: متوسط موزون (يختلف عن MAP). الربط بالذكاء الاصطناعي: تقدير احتمال نقر «بايزي».

مثال (3-5.18): التنبؤ الخلفي المعطيات: نريد $p(x_{new} \mid X)$. المطلوب: التوزيع التنبّؤي. الحل: الخطوة 1: $\int p(x_{new} \mid \theta) p(\theta \mid X) d\theta$. النتيجة: تنبّؤ يعكس عدم اليقين. الربط بالذكاء الاصطناعي: التنبؤ في NN Bayesian (صورة كاملة لا نقطية).

مثال (4-5.18): متوسط بايزي للتقييمات المعطيات: عنصر بـ k تقييم من n، سابق متوسط m_0. المطلوب: تقدير النجوم. الحل: الخطوة 1: $\frac{k\bar{r} + (n_0)m_0}{k+n_0}$ (صيغة IMDB). النتيجة: يخفّف تقييمات قليلة. الربط بالذكاء الاصطناعي: ترتيب العناصر ذات العيّنات القليلة.

مثال (5-5.18): أخذ العينات من الخلفيّة (MCMC) المعطيات: الخلفيّة غير مغلقة. المطلوب: حساب الوسط. الحل: الخطوة 1: نولّد عيّنات $\theta^{(s)} \sim p(\theta \mid X)$ (Metropolis/HMC). الخطوة 2: $\hat{\theta} \approx \frac{1}{S}\sum \theta^{(s)}$. النتيجة: تقدير عددي. الربط بالذكاء الاصطناعي: استدلال بايزي في النماذج العميقة.

مثال (6-5.18): الانحدار الخطّي البايزي المعطيات: $w \sim \mathcal{N}(0, \tau^2 I)$. المطلوب: الوسط الخلفي لـ w. الحل: الخطوة 1: $\mathbb{E}[w \mid X, y] = (X^\top X/\sigma^2 + I/\tau^2)^{-1} X^\top y/\sigma^2$. النتيجة: ريدج بايزي (منتظم). الربط بالذكاء الاصطناعي: تقدير أوزان مع عدم يقين.

مثال (7-5.18): متوسط المسؤوليات (GMM) المعطيات: كل نقطة تنتمي لخليط. المطلوب: تقدير المعاملات. الحل: الخطوة 1: نأخذ وسط المسؤوليات في EM. النتيجة: تقدير «ناعم». الربط بالذكاء الاصطناعي: تجميع ناعم (soft assignment).

مثال (18.5-8): عدم اليقين في التنبؤ المعطيات: خلفيّة واسعة. المطلوب: ماذا يعني؟ الحل: الخطوة 1: التوزيع التنبّؤي منتشر. النتيجة: نموذج «لا يعرف». الربط بالذكاء الاصطناعي: كشف عدم اليقين (uncertainty quantfiication).

مثال (18.5-9): بايز ضد MAP عند عدم التماثل المعطيات: خلفيّة منحرفة يمنى. المطلوب: أيهما أعلى؟ الحل: الخطوة 1: الوسط > الوضع. النتيجة: يختلفان. الربط بالذكاء الاصطناعي: تفضيل متوسط الخسارة المتوقّعة.

مثال (18.5-10): توسّط نماذج (Bayesian Averaging) Model المعطيات: نماذج $M_1, \dots, M_m$ باحتمال خلفي. المطلوب: تنبّؤ مدمج. الحل: الخطوة 1: $\sum_k p(M_k \mid X)\, \hat{y}_k$. النتيجة: تجميع بايزي. الربط بالذكاء الاصطناعي: تقليل تباين التنبؤ عبر نماذج.

مثال (18.5-11): عينة صغيرة — أثر السابق المعطيات: $n = 2$ فقط. المطلوب: الوسط الخلفي. الحل: الخطوة 1: يميل بقوة نحو μ_0. النتيجة: السابق يسود. الربط بالذكاء الاصطناعي: ضبط نموذج من بيانات قليلة.

مثال (18.5-12): Dropout MC كتقريب بايزي المعطيات: شبكة مع dropout عند الاختبار. المطلوب: ماذا يقدّر؟ الحل: الخطوة 1: متوسط تمريرات dropout $\approx$ الوسط الخلفي التقريبي. النتيجة: تقدير عدم يقين رخيص. الربط بالذكاء الاصطناعي: Learning Deep Bayesian عملياً.

مثال (18.5-13): خسارة تربيعية مقابل 0-1 المعطيات: نغيّر دالّة الخسارة. المطلوب: المقدّر الأمثل. الحل: الخطوة 1: التربيعية $\Rightarrow$ الوسط؛ 0-1 $\Rightarrow$ الوضع. النتيجة: الخسارة تحدّد المقدّر. الربط بالذكاء الاصطناعي: اختيار معيار التقييم يغيّر التقدير.

مثال (18.5-14): فاصل مصداقية (credible interval) المعطيات: خلفيّة معلومة. المطلوب: فاصل 95٪. الحل: الخطوة 1: نأخذ الوسيط المركزي 95٪ من الخلفيّة. النتيجة: تفسير مباشر «95٪ احتمال». الربط بالذكاء الاصطناعي: تقارير ثقة قابلة للتفسير للمديرين.

مثال (18.5-15): لماذا البايزي أقوى وأصعب المعطيات: تجميع كامل للمعرفة السابقة. المطلوب: المقايضة. الحل: الخطوة 1: دقّة على حساب تكامل/عيّنات. النتيجة: تكلفة حسابية أعلى. الربط بالذكاء الاصطناعي: متى نستحقّ تكلفة MCMC.

أخطاء شائعة

- الخلط بين الوسط الخلفي والوضع (MAP).
- الظن أن البايزي دائماً غير متحيّز — يعتمد على السابق.
- نسيان أن التوزيع التنبّؤي يدمج عدم اليقين (لا يأخذ نقطة).
- استخدام MCMC دون تشخيص التقارب.

تحت شروط انتظام، المقدّر الأقصى الاحتمالي متّسق وطبيعي:

$$\sqrt{n}\,(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}\big(0,\ I(\theta_0)^{-1}\big) \tag{5.18}$$

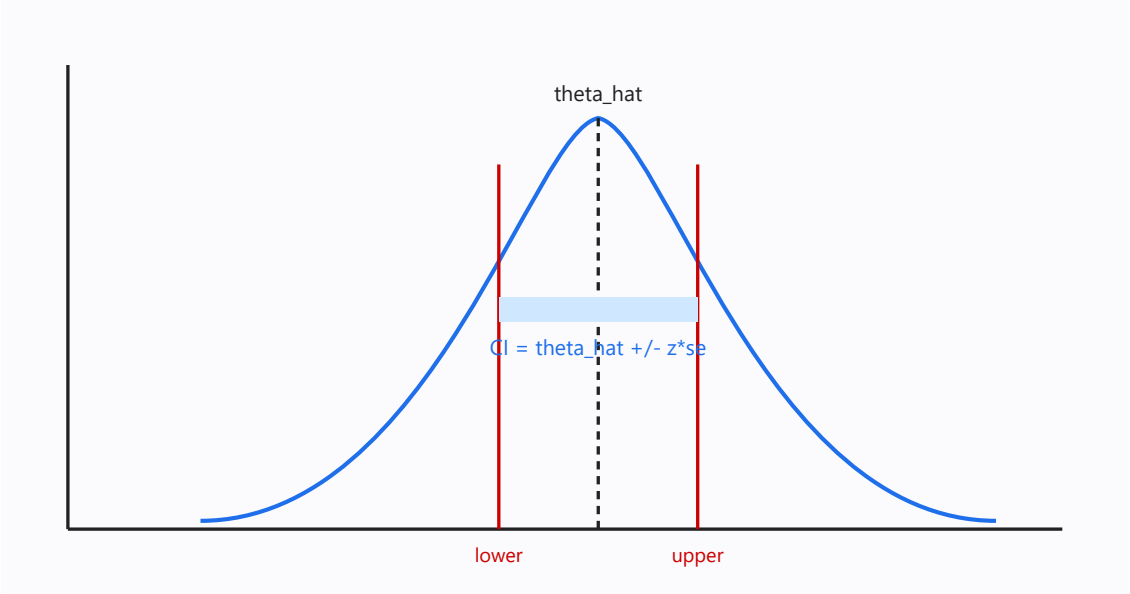
ومنه فترة ثقة تقاربية (Wald): $\hat{\theta}_n \pm z_{\alpha/2}\,\widehat{\mathrm{se}}$، حيث $\widehat{\mathrm{se}} = 1/\sqrt{n\hat{I}}$.

جدول الرموز

الرمز	المعنى
$I(\theta)$	معلومات فيشر
$\widehat{\mathrm{se}}$	الخطأ المعياري المقدّر
$z_{\alpha/2}$	كمّية التوزيع الطبيعي القياسي

الرسم

<figure> الشكل<figcaption> 5.18: الفترة $\hat{\theta} \pm z \cdot \widehat{\mathrm{se}}$ تغطّي θ بنسبة تقاربية $1-\alpha$</figcaption>. </figure>



شكل ٥.١٨: *
فترة الثقة: تقدير ± هامش

البرهان (مخطّط)

نوسّع $\nabla \ell(\theta_0)$ حول $\hat{\theta}_n$، بـ $\frac{1}{n}\nabla \ell \to 0$ واحتمال $\frac{1}{n}\nabla^2 \ell \to -I(\theta_0)$، نحصل على $\sqrt{n}(\hat{\theta}_n - \theta_0) \approx I^{-1}\frac{1}{\sqrt{n}}\nabla \ell$. وبمركزية الحدّ نحصل على الغاوسي. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.18): فترة ثقة للمتوسط الغاوسي المعطيات: $\bar{x}=10$، $s=2$، $n=100$. المطلوب: فترة 95٪. الحل: الخطوة 1: $\widehat{\mathrm{se}} = 2/\sqrt{100} = 0.2$، $z = 1.96$. الخطوة 2: $10 \pm 1.96 \times 0.2 = (9.608, 10.392)$. النتيجة: الفترة. الربط بالذكاء الاصطناعي: فاصل ثقة لدقّة نموذج منشور.

مثال (2-6.18): فترة لنسبة برنولي (Wald) المعطيات: $\hat{p}=0.7$، $n=400$. المطلوب: فترة 95٪. الحل: الخطوة 1: $\widehat{\mathrm{se}} = \sqrt{0.7 \times 0.3/400} \approx 0.0229$. الخطوة 2: $0.7 \pm 1.96 \times 0.0229 = (0.655, 0.745)$. النتيجة: الفترة. الربط بالذكاء الاصطناعي: ثقة في معدّل نقر مقدّر.

مثال (3-6.18): فترة ويلسون المعطيات: نفس ما سبق. المطلوب: ويلسون أفضل للأطراف. الحل: الخطوة 1: $\tilde{p} = (k + z^2/2)/(n + z^2)$، $\tilde{n} = n + z^2$. الخطوة 2: فترة أضيق عند الأطراف. النتيجة: تفضيل ويلسون للنسب القصوى. الربط بالذكاء الاصطناعي: تقدير نسبة نادرة بدقّة.

مثال (18.6-4): عرض الفترة و n المعطيات: نريد عرض ≤ 0.04 لنسبة. المطلوب: n المطلوب. الحل: الخطوة 1: $2 \times 1.96\sqrt{0.25/n} \leq 0.04 \Rightarrow n \geq (1.96)^2 \times 0.25/0.02^2 = 2401$. النتيجة: $n \approx 2401$. الربط بالذكاء الاصطناعي: ميزانية وسوم لعرض ثقة مطلوب.

مثال (18.6-5): فترة للتباين المعطيات: χ^2 للتباين الغاوسي. المطلوب: الفترة. الحل: الخطوة 1: $\frac{(n-1)s^2}{\chi^2_{1-\alpha/2}} \leq \sigma^2 \leq \frac{(n-1)s^2}{\chi^2_{\alpha/2}}$. النتيجة: فترة مبنية على χ^2. الربط بالذكاء الاصطناعي: ثقة في تباين ضوضاء المستشعر.

مثال (18.6-6): فترة معامل الانحدار المعطيات: $\hat{w}_j$ و $\widehat{\text{se}}(\hat{w}_j)$. المطلوب: الفترة. الحل: الخطوة 1: $\hat{w}_j \pm z\,\widehat{\text{se}}$. النتيجة: دلالة المعامل. الربط بالذكاء الاصطناعي: أيّ ميزة ذات أثر معنون؟

مثال (18.6-7): فترة الفرق بين متوسطين المعطيات: مجموعتان مستقلّتان. المطلوب: الفترة. الحل: الخطوة 1: $\widehat{\text{se}} = \sqrt{s_1^2/n_1 + s_2^2/n_2}$. النتيجة: فاصل A/B. الربط بالذكاء الاصطناعي: قرار نشر ميزة.

مثال (18.6-8): تغطية احتمالية المعطيات: فترة ٪95. المطلوب: معناها. الحل: الخطوة 1: «لو تكرّرنا، ٪95 من الفترات تحتوي θ» لا «٪95 احتمال لـ θ». النتيجة: تفسير تردّدي. الربط بالذكاء الاصطناعي: تجنّب سوء تفسير التقارير.

مثال (18.6-9): خطأ معياري مقارب لـ MLE المعطيات: $I(\hat{\theta})$ مقدّر. المطلوب: $\widehat{\text{se}}$. الحل: الخطوة 1: $1/\sqrt{nI(\hat{\theta})}$. النتيجة: فترة Wald. الربط بالذكاء الاصطناعي: فترة ثقة لمعامل شبكة.

مثال (18.6-10): فترة بواسون المعطيات: $\sum x_i = 50$، $n = 10$، $\hat{\lambda} = 5$. المطلوب: فترة. الحل: الخطوة 1: $\widehat{\text{se}} = \sqrt{5/10} \approx 0.707$. الخطوة 2: $5 \pm 1.96 \times 0.707 = (3.61, 6.39)$. النتيجة: الفترة. الربط بالذكاء الاصطناعي: ثقة في معدّل أحداث.

مثال (18.6-11): فترة أسّية (معدّل) المعطيات: $\hat{\lambda} = 1/\bar{x}$، $\text{Var}(\hat{\lambda}) \approx \lambda^2/n$. المطلوب: الفترة. الحل: الخطوة 1: $\hat{\lambda} \pm z\,\hat{\lambda}/\sqrt{n}$. النتيجة: تقاربية. الربط بالذكاء الاصطناعي: ثقة في MTBF.

مثال (18.6-12): التنبؤ مقابل الثقة المعطيات: نريد فاصلاً لقيمة جديدة لا للمعامل. المطلوب: الفرق. الحل: الخطوة 1: فاصل التنبؤ يضيف تباين الضوضاء. النتيجة: أعرض. الربط بالذكاء الاصطناعي: نطاق تنبّؤ خدمة استدلال.

مثال (18.6-13): فترة أحادية الجانب المعطيات: نهتم بألّا يتجاوز الحدّ الأعلى. المطلوب: الفترة. الحل: الخطوة 1: $(-\infty, \hat{\theta} + z_\alpha \widehat{\text{se}}]$. النتيجة: ضمانة عليا. الربط بالذكاء الاصطناعي: سقف زمن استجابة.

مثال (18.6-14): bootstrap (تمهيد) المعطيات: لا توزيع مغلق. المطلوب: فترة. الحل: الخطوة 1: نعيد معاملة العيّنة B مرة ونأخذ الكمّيات. النتيجة: فترة غير معتمدة على افتراض غاوسي. الربط بالذكاء الاصطناعي: فواصل ثقة لنماذج معقّدة.

مثال (18.6-15): التغطية الفعلية المعطيات: n صغير والتماثل تقاربي ضعيف. المطلوب: الخطر. الحل: الخطوة 1: التغطية الفعلية < الاسمية. النتيجة: نحتاج تصحيحاً أو بايزي. الربط بالذكاء الاصطناعي: لا نثق بفواصل صغيرة العيّنة.

أخطاء شائعة

- تفسير الفترة كاحتمال للمعامل (خطأ تردّدي/بايزي).
- استخدام Wald عند n صغير أو نسبة قصوى.
- نسيان أن $\widehat{\text{se}}$ نفسه مقدّر ومتأرجح.
- خلط فاصل الثقة بفاصل التنبؤ.

مبرهنة نيمان–بيرسون:

لأكثر اختبار قوة عند مستوى α بين $H_0 : \theta = \theta_0$ و $H_1 : \theta = \theta_1$، ارفض H_0 حين:

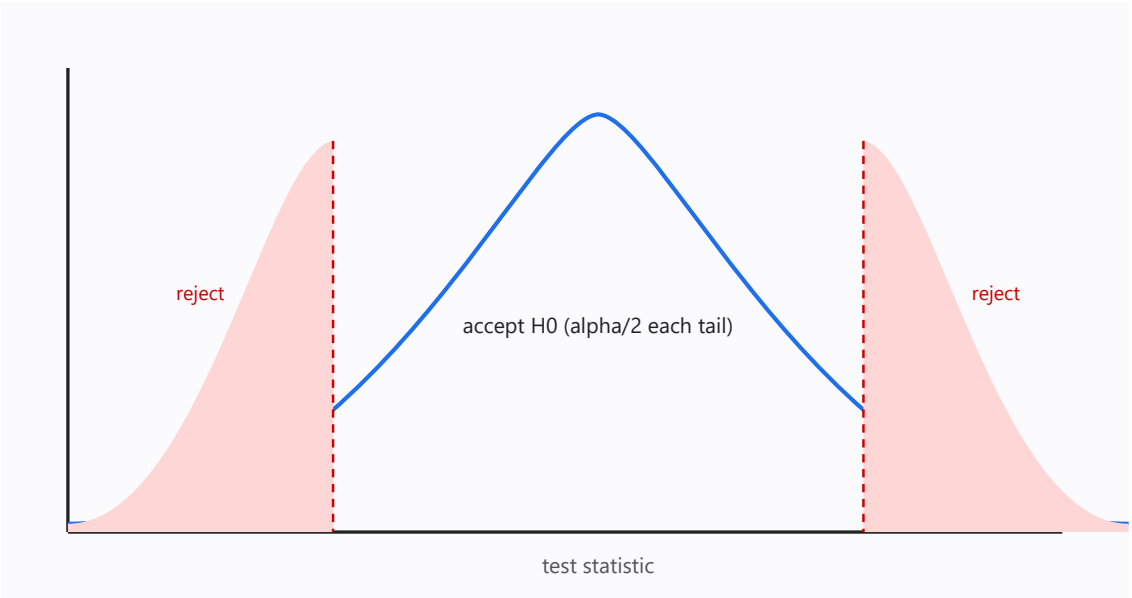
$$\Lambda(x) = \frac{\mathcal{L}(\theta_0 \mid x)}{\mathcal{L}(\hat{\theta} \mid x)} \leq c, \qquad \hat{\theta} = \text{MLE} \tag{6.18}$$

جدول الرموز

الرمز	المعنى
H_0, H_1	الفرضية الصفرية والبديلة
Λ	نسبة الاحتمال (Likelihood Ratio)
α, β	خطأ النوع الأول والثاني

الرسم

<figure> الشكل<figcaption> 6.18: تحت H_0 منطقة الرفض (الذيل) تحقّق المستوى α؛ القوة =



شكل ٦.١٨: *
اختبار الفرضيات: منطقتا القبول والرفض

$1-\beta$.</figcaption></figure>

البرهان (مخطّط)

بقاعدة نيمان–بيرسون، الاختبار الأكثر قوة يقبل شكل نسبة الكثافة $k \leq p_1/p_0$. للاختبارات المركّبة نأخذ $\sup_{\theta_0} / \sup_{\theta_1}$ لنحصل على LRT. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.18): اختبار متوسط غاوسي المعطيات: $H_0 : \mu = \mu_0$ مقابل $H_1 : \mu \neq \mu_0$، σ معلوم. المطلوب: الإحصاء. الحل: الخطوة 1: $Z = \frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$ تحت H_0. الخطوة 2: نرفض عند $|Z| > z_{\alpha/2}$. النتيجة: اختبار Z. الربط بالذكاء الاصطناعي: هل تغيّر أداء النموذج signfiicantly؟

مثال (2-7.18): p-value المعطيات: لوحظ $Z = 2.3$. المطلوب: القيمة الاحتمالية. الحل: الخطوة 1: $p = 2(1 - \Phi(2.3)) \approx 2(0.0107) = 0.0214$. النتيجة: دلالة عند ٥٪. الربط بالذكاء الاصطناعي: تقرير دلالة تحسّن A/B.

مثال (3-7.18): خطأ النوع الأول والثاني المعطيات: $\alpha = 0.05$، القوة $1 - \beta = 0.8$. المطلوب: المعنى. الحل: الخطوة 1: α = رفض خاطئ لـ H_0؛ β = قبول خاطئ. النتيجة: مقايضة عبر حجم العيّنة. الربط بالذكاء الاصطناعي: تكلفة نشر ميزة سيّئة مقابل تفويت جيدة.

مثال (4-7.18): LRT للتباين المعطيات: غاوسي، نختبر $\sigma^2 = \sigma_0^2$. المطلوب: نسبة الاحتمال. الحل: الخطوة 1: $\Lambda = (\hat{\sigma}^2/\sigma_0^2)^{n/2} e^{-n/2(\hat{\sigma}^2/\sigma_0^2 - 1)}$. النتيجة: مرتبط بـ χ^2. الربط بالذكاء الاصطناعي: فحص استقرار تباين الضوضاء.

مثال (5-7.18): اختبار مربّع كاي (Goodness-of-fit) المعطيات: تواترات ملاحَظة O_i ومتوقّعة E_i. المطلوب: الإحصاء. الحل: الخطوة 1: $X^2 = \sum \frac{(O_i - E_i)^2}{E_i} \sim \chi^2_{k-1}$. النتيجة: رفض عند تجاوز الكمّية. الربط بالذكاء الاصطناعي: هل توزيع التنبؤ يطابق الملاحَظ؟

مثال (6-7.18): اختبار متعدّد ANOVA) تمهيد) المعطيات: مقارنة K مجموعات. المطلوب: فكرة. الحل: الخطوة 1: نسبة تباين بين/داخل المجموعات. النتيجة: LRT عامّ. الربط بالذكاء الاصطناعي: أي نسخة نموذج أفضل؟

مثال (7-7.18): اختبار تحسّن مصنّف المعطيات: دقّتان 91.0 و93.0 على نفس الاختبار. المطلوب: هل الفرق دالّ؟ الحل: الخطوة 1: اختبار مكمّل مكدّس (McNemar) على أزواج الأخطاء. النتيجة: يمنع الخداع بالعيّنة نفسها. الربط بالذكاء الاصطناعي: مقارنة نماذج بعدالة.

مثال (8-7.18): اختبارات متعدّدة (Bonferroni) المعطيات: $m = 20$ اختباراً، $\alpha = 0.05$. المطلوب: الضبط. الحل: الخطوة 1: العتبة لكل $0.05/20 = 0.0025$=. النتيجة: تحكّم في الخطأ العائلي. الربط بالذكاء الاصطناعي: اختيار ميزات من اختبارات كثيرة.

مثال (9-7.18): معدّل الاكتشاف الخاطئ (FDR) المعطيات: m كبير، نريد طاقة أعلى من بونفيرّوني. المطلوب: إجراء بنجاميني–هوتشبرغ. الحل: الخطوة 1: نرتّب الـ p-values ونرفض الأصغر حتى $p_{(k)} \leq \frac{k}{m}\alpha$. النتيجة: تحكّم FDR. الربط بالذكاء الاصطناعي: اكتشاف الإشارات في بيانات عالية الأبعاد.

مثال (10-7.18): اختبار نسبة الاحتمال للنماذج المعطيات: نموذج بسيط مقابل معقّد. المطلوب: LRT. الحل: الخطوة 1: $-2\log\Lambda \xrightarrow{d} \chi^2_{df=\Delta}$. النتيجة: اختيار النموذج. الربط بالذكاء الاصطناعي: هل نضيف طبقة/ميزة؟

مثال (11-7.18): بايز ضد تردّدي المعطيات: عامل بايز $BF = \frac{p(X|H_1)}{p(X|H_0)}$. المطلوب: التفسير. الحل: الخطوة 1: $BF > 1$ يدعم H_1، يقيس الدليل لا القرار. النتيجة: بديل بايزي. الربط بالذكاء الاصطناعي: مقارنة نماذج عبر الأدلّة.

مثال (12-7.18): اختبار توزيع الإنتاج المعطيات: هل انحرف توزيع المدخلات؟ المطلوب: LRT على معاملات. الحل: الخطوة 1: نختبر تطابق معاملات التوزيع. النتيجة: كشف covariate shfit. الربط بالذكاء الاصطناعي: إنذار تدهور النموذج (drfit).

مثال (13-7.18): القوة الإحصائية المعطيات: أثر بحجم d، نريد قوة 0.9. المطلوب: n المطلوب. الحل: الخطوة 1: $n \propto (z_\alpha + z_\beta)^2/d^2$. النتيجة: حجم عيّنة للكشف. الربط بالذكاء الاصطناعي: تجربة A/B مصمّمة مسبقاً.

مثال (14-7.18): اختبار غير معلمي (مكاني) المعطيات: لا افتراض غاوسي. المطلوب: بديل. الحل: الخطوة 1: اختبار مان–ويتني (رتب). النتيجة: توزيع حرّ. الربط بالذكاء الاصطناعي: مقارنة عند شذوذ كبير.

مثال (15-7.18): p-hacking المعطيات: نجرّب كثيراً حتى نحصل p<0.05. المطلوب: الخطر. الحل: الخطوة 1: دون ضبط تعدّدي، معدّل الخطأ يرتفع. النتيجة: نتائج زائفة. الربط بالذكاء الاصطناعي: لماذا نثبّت بروتوكول التقييم مسبقاً.

أخطاء شائعة

- اعتبار $p<0.05$ «صحيحاً» — هو دلالة لا حقيقة.
- نسيان ضبط التعدّد في اختبارات متكرّرة.
- الخلط بين القوة و α.
- استخدام نفس عيّنة الاختبار للاختيار وللتقييم.

مع متغيّر كامن Z، نكرّر:

$$Q(\theta \mid \theta^{(t)}) = \mathbb{E}_{Z \mid X, \theta^{(t)}}\big[\log p(X, Z \mid \theta)\big], \qquad \theta^{(t+1)} = \arg\max_{\theta} Q(\theta \mid \theta^{(t)}) \tag{7.18}$$

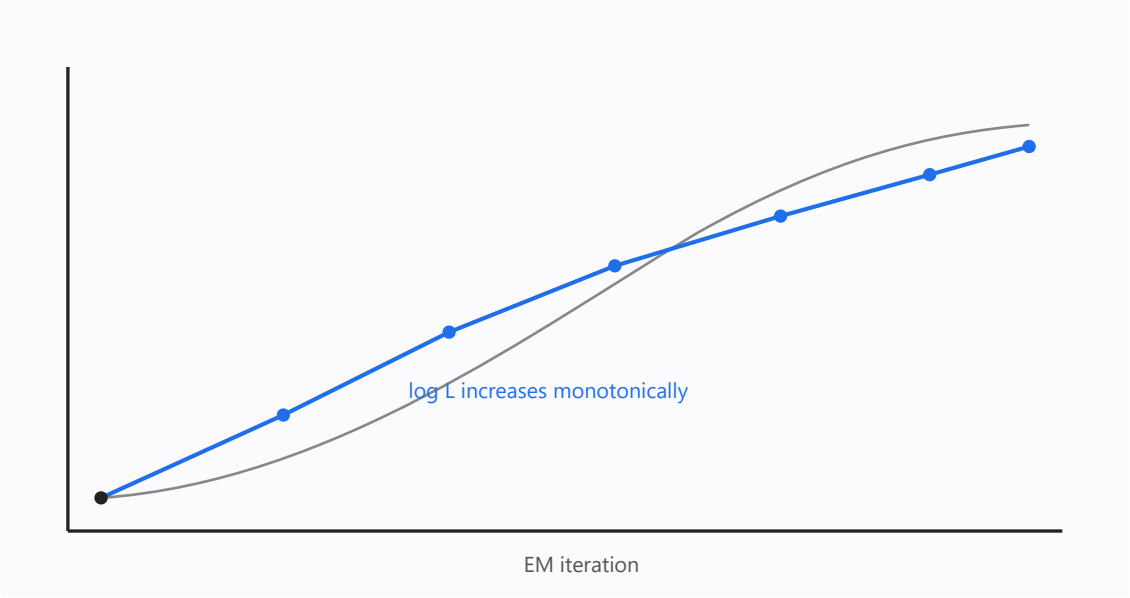
وتتزايد دالة الاحتمال رتيباً: $\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$.

جدول الرموز

الرمز	المعنى
Z	المتغيّر الكامن
Q	دالة التوقّع
$\theta^{(t)}$	تقدير الخطوة t

الرسم

<figure> الشكل<figcaption> 7.18: كل تكرار E) ثم M) لا ينقص الاحتمال؛ المسار يتقارب لنقطة جبلية



شكل ٧.١٨: *
خوارزمية EM: صعود رتيب في الاحتمال

محلية.</figcaption> </figure>

البرهان (مخطّط)

بنموذج تفكيك :(ELBO) $\log p(X \mid \theta) = \mathcal{L}(q, \theta) + D_{KL}(q \| p(Z \mid X, \theta))$؛ بتثبيت $\theta^{(t)}$ نختار $q = p(Z \mid X, \theta^{(t)})$ فتختفي KL، ثمّ نعظّم θ فتنخفض KL — فيزداد اللوغاريتم. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.18): GMM أحادي البعد المعطيات: نقطتان مكوّنتان، $\pi, \mu_1, \mu_2, \sigma^2$. المطلوب: خطوة E ثم M. الحل: الخطوة 1: E: مسؤوليات $\gamma_i = P(z_i = k \mid x_i)$. الخطوة 2: M: تحديث الأوزان والمتوسطات بأوزان γ. النتيجة: تجميع ناعم. الربط بالذكاء الاصطناعي: تجميع GMM clustering.

مثال (2-8.18): GMM ثنائي الأبعاد المعطيات: نقاط (x, y) من مكوّنين غاوسيين. المطلوب: المعاملات. الحل: الخطوة 1: E تحسب المسؤوليات بكثافة ثنائية. الخطوة 2: M تحدّث المتوسطات والتغاورات. النتيجة: تقدير كامل التغاور. الربط بالذكاء الاصطناعي: تجميع بيانات صور/ميزات.

مثال (3-8.18): كـ-means كـ EM صلب المعطيات: نريد تجميع صلباً. المطلوب: العلاقة. الحل: الخطوة 1: مع $\sigma \to 0$ يصير EM تخصيصاً صلباً = k-means. النتيجة: k-means حالة حدّية من EM. الربط بالذكاء الاصطناعي: تهيئة k-means بتجميع ناعم.

مثال (4-8.18): عملة بثلاث حالات (مخفي) المعطيات: نختار عملة مجهولة ثم نرمي. المطلوب: تقدير احتمالات العملات. الحل: الخطوة 1: E: احتمال أيّ عملة ولّدت كل رمية. الخطوة 2: M: إعادة تقدير الاحتمالات. النتيجة: EM كلاسيكي. الربط بالذكاء الاصطناعي: نماذج مختلطة بمكوّن مخفي.

مثال (5-8.18): HMM — بيوم–فلش (Baum–Welch) المعطيات: سلسلة مخفيّة ذات ملاحَظات. المطلوب: المعاملات. الحل: الخطوة 1: E عبر تمرير للأمام/للخلف. الخطوة 2: M يحدّث احتمالات الانتقال/الإصدار. النتيجة: تدريب HMM. الربط بالذكاء الاصطناعي: نمذجة تسلسل (كلام/نص).

مثال (6-8.18): PCA احتمالي (PPCA) المعطيات: بيانات من فضاء كامن منخفض. المطلوب: تقدير W, σ^2. الحل: الخطوة 1: E تحسب توقع الكامن. الخطوة 2: M تحدّث W. النتيجة: تقليل أبعاد بايزي. الربط بالذكاء الاصطناعي: استخراج ميزات كامنة.

مثال (7-8.18): نموذج لغوي بكلمات مفقودة المعطيات: بعض الكلمات مُقنّعة. المطلوب: تقدير الاحتمالات. الحل: الخطوة 1: E يحسب توزيع الكلمة المفقودة. الخطوة 2: M يحدّث تواترات n-gram. النتيجة: تدريب برموز مخفيّة. الربط بالذكاء الاصطناعي: نماذج اللغات الضخمة (masked LM).

مثال (8-8.18): تقارب رتيب المعطيات: نريد ضمانة. المطلوب: البرهان. الحل: الخطوة 1: ELBO يزداد كل تكرار. النتيجة: لا ينقص الاحتمال أبداً. الربط بالذكاء الاصطناعي: استقرار التدريب غير المتقارب بوضوح.

مثال (9-8.18): مستوى جبلي محلي المعطيات: EM يتوقّف عند نقطة غير عالمية. المطلوب: الحلّ. الحل: الخطوة 1: نبدأ من عدّة تهيئات ونختار الأعلى احتمالاً. النتيجة: تفادي الأفضلية المحلية. الربط بالذكاء الاصطناعي: تهيئة متعدّدة لـ GMM.

مثال (10-8.18): MAP-EM المعطيات: نريد تنظيم. المطلوب: التعديل. الحل: الخطوة 1: نضيف $\log p(\theta)$ لـ Q. النتيجة: EM منظّم. الربط بالذكاء الاصطناعي: استقرار مع معاملات مخفيّة كثيرة.

مثال (11-8.18): تنبؤ ناعم المعطيات: نريد تسمية نقطة جديدة. المطلوب: بعد EM. الحل: الخطوة 1: نحسب مسؤولياتها بالمعاملات المعلّمة. النتيجة: تجميع ناعم للإنتاج. الربط بالذكاء الاصطناعي: تصنيف متعدّد المكوّنات.

مثال (12-8.18): ميزات خبيرة مختلطة (MoE) المعطيات: خبراء E_k بوزن توجيه g. المطلوب: تدريب. الحل: الخطوة 1: E تحسب أوزان الخبراء، M يحدّث g والخبراء. النتيجة: MoE. الربط بالذكاء الاصطناعي: Mixture-of-Experts في النماذج الضخمة.

مثال (18.8-13): عدم اليقين في الكامن المعطيات: معاملات مقدّرة لكن Z مجهول. المطلوب: تقدير. الحل: الخطوة 1: نأخذ وسط $p(Z \mid X, \hat{\theta})$. النتيجة: تقدير ناعم للكامن. الربط بالذكاء الاصطناعي: تفسير تجميع/تخصيص.

مثال (18.8-14): EM مقابل تدرّج المعطيات: بديل للتحسين. المطلوب: متى نفضّل EM؟ الحل: الخطوة 1: عند كامن بسيط وهدف معقّد، EM مستقرّ. النتيجة: بديل SGD. الربط بالذكاء الاصطناعي: خوارزميات تعلّم غير م supervised.

مثال (18.8-15): تطبيق على توصية matrix) (completion المعطيات: مصفوفة تفضيلات بثقوب. المطلوب: تعبئة. الحل: الخطوة 1: نموذج العامل الكامن عبر EM على القيم المفقودة. النتيجة: تنبّؤ بالثقوب. الربط بالذكاء الاصطناعي: التصفية التعاونية collaborative) (filtering.

أخطاء شائعة

- الظن أن EM يصل للمستوى العالمي — يقع في محلي.
- نسيان أن التقارب «رتيب» لا «سريع» (خطيّ بطيء أحياناً).
- تهيئة سيّئة تؤدي لانهيار مكوّن.
- خلط المسؤوليات (E) مع التخصيص الصلب النهائي.

ملخّص النظريات

النظرية	القاعدة	الأهمّ في الذكاء الاصطناعي
MLE 2.18	$\arg\max \sum \log p(x_i \mid \theta)$	تدريب = تقليل الإنتروبيا المتقاطعة
MAP 3.18	$\arg\max \log p(\theta) + \ell$	التنظيم L1/L2
4.18 خصائص	$\text{MSE} = Var + Bias^2$	توازن bias–variance
5.18 بايزي	$\mathbb{E}[\theta \mid X]$	قياس عدم اليقين
6.18 ثقة	$\hat{\theta} \pm z\,\widehat{se}$	فواصل ثقة للتقارير
7.18 فرضيات	رفض عند $\Lambda \leq c$	قرار نشر/كشف drfit
EM 8.18	تكرار E ثم M	GMM/HMM/MoE

عشرون تمريناً (مع إجابات مختصرة)

١. أثبت أن MLE = OLS غاوسي. (انظر 18.2-6)

٢. عدّل λ في ريدج ليطابق سابقاً غاوسياً. $(\lambda = \sigma^2/\tau^2)$

٣. لماذا $\hat{\sigma}^2_{MLE}$ متحيّز؟ (يقسّم على n)

٤. أكمل: $MSE = V + (B)^2$. (Bias)

٥. متى يفوز جيمس–ستين على المتوسطات المنفصلة؟ $(K \geq 3)$

٦. عبّر عن MAP للوجستي. (Cross-Entropy + $\frac{\lambda}{2}\|w\|^2$)

٧. متى يساوي MAP الوسط الخلفي؟ (خلفيّة متماثلة تاماً وكافية)

٨. اكتب فترة ويلسون لنسبة. $(\tilde{p} \pm z\sqrt{\tilde{p}(1-\tilde{p})/\tilde{n}})$

٩. ما الفرق بين فاصل ثقة وتنبّؤي؟ (الأخير يضيف تباين الضوضاء)

١٠. عبّر عن خطأ المعياري المقارب لـ MLE. $(1/\sqrt{n\hat{I}})$

١١. متى تستخدم bootstrap بدل Wald؟ (توزيع غير مغلق/عيّنة صغيرة)

١٢. اكتب نسبة الاحتمال لـ LRT. $(\mathcal{L}(\theta_0)/\mathcal{L}(\hat{\theta}))$

١٣. ما عقوبة اختبارات متعدّدة دون ضبط؟ (ارتفاع معدّل الخطأ العائلي)

١٤. اربط FDR ببونفيرّوني. (FDR أقلّ تحفّظاً)

١٥. برهن رتوبة EM عبر ELBO. (انظر 8.18 برهان)

١٦. متى يصير EM = k-means؟ $(\sigma \to 0)$

١٧. عدّد تطبيقين لـ EM في ML، (GMM، HMM، PPCA، MoE)

١٨. لماذا MAP ليس بايزياً كاملاً؟ (يأخذ الوضع لا التوزيع)

١٩. احسب فترة 95٪ لـ $\bar{x} = 5, s = 1, n = 25$. (5 ± 0.392)

٢٠. اشرح متى نفضّل بايزي على تردّدي. (عند أهمّية عدم اليقين/سابق قوي)

فهرس الرموز

الرمز	المعنى
$\mathcal{L}, \ell$	الاحتمال ولوغاريتمه
$\hat{\theta}_{MLE/MAP}$	التقديرات
$I(\theta)$	معلومات فيشر
Λ	نسبة الاحتمال
Q	دالة EM

مراجع

- Berger & Casella — *Statistical Inference*.
- Bishop — *Pattern Recognition and Machine Learning* (الفصلان 2 و9).
- Friedman Tibshirani, Hastie, — *The Elements of Statistical Learning*.
- Murphy — *Machine Learning: A Probabilistic Perspective*.
- Wasserman — *All of Statistics*.

السلاسل الزمنية والعمليات العشوائية

«المتغيّر لا يقف وحده: ما حدث بالأمس يكتب احتمال الغد.»

بهذا الفصل يُختتم الجزء الثالث (الاحتمالات والإحصاء). بعد أن بنينا فضاءات الاحتمال (13)، التوزيعات (14)، المتوقّع والتباين (15)، بايز والحقول العشوائية (16)، مترابحات التركيز (17)، والإستدلال والتقدير MLE/MAP (18)، ننتقل إلى **الزمن**: كيف نمذج متغيّرات تعتمد على ماضيها، وكيف نتنبّأ بمستقبلها، وكيف نبني عمليات عشوائية متّصلة من ولادة الأحداث إلى الحركة البراونية التي تقف خلف نماذج الانتشار.
سبع نظريات:

- **2.19 الثبات والارتباط الذاتي** — شرط أن تكون السلسلة قابلة للنمذجة.
- **3.19 نماذج AR** — الانحدار على الذات.
- **4.19 نماذج MA و ARMA** — الصدمة المتراكمة والصيغة العامّة.
- **5.19 المشي العشوائي و ARIMA** — التعامل مع عدم الثبات بالتفاضل.
- **6.19 عمليات بواسون** — نمذجة وصول الأحداث.
- **7.19 الحركة البراونية و SDE** — العمليات المتّصلة وأساس الانتشار.
- **8.19 المارتنغيالات والتوقّف الأمثل** — اللعب العادل ونظرية التوقّف.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

نعرّف السلسلة الزمنية X_t على أزمنة $t \in \mathbb{Z}$ (منفصلة) أو $t \geq 0$ (متّصلة).

الرمز	المعنى
X_t	قيمة السلسلة عند الزمن t
$\gamma(h)$	دالة التغوّر الذاتي عند التأخّر h
$\rho(h)$	دالة الارتباط الذاتي ACF
ε_t	الابتكار/الضوضاء البيضاء
L	مؤثّر التأخّر $LX_t = X_{t-1}$
$\mathcal{F}_t$	الترشيح (filtration) حتى t

الضوضاء البيضاء: $\varepsilon_t \sim (0, \sigma^2)$ مستقلّة متماثلة التوزيع، $\gamma(0) = \sigma^2$ و $\gamma(h) = 0$ لـ $h \neq 0$.

سلسلة **ثابتة ضعيفاً** إذا كان متوسطها ثابتاً وتغوّرها يعتمد على التأخّر فقط:

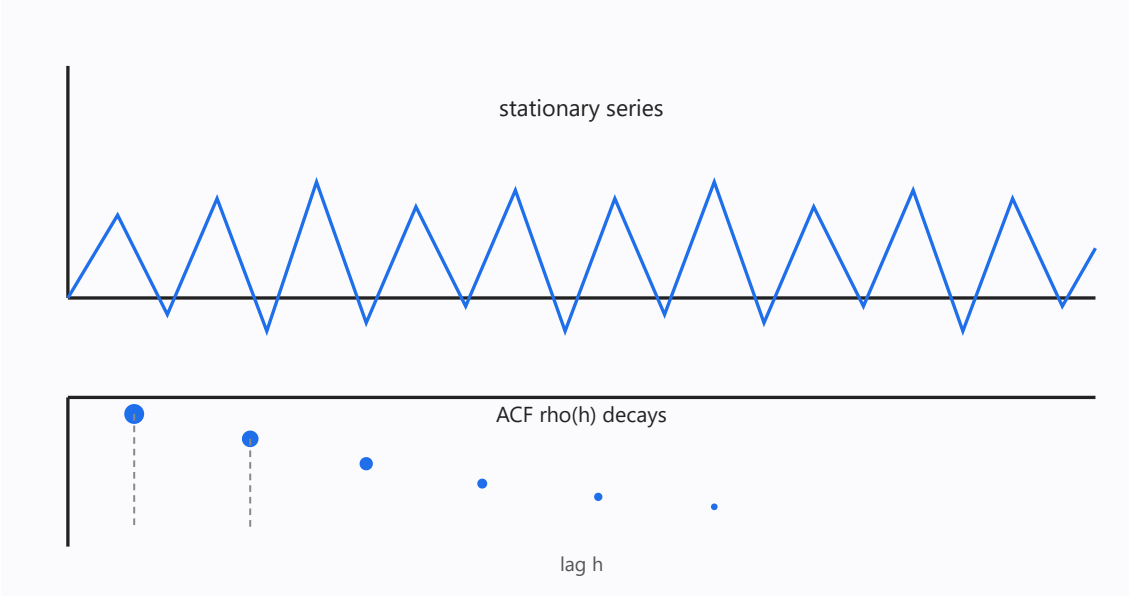
$$\mathbb{E}[X_t] = \mu, \qquad \gamma(h) = \operatorname{Cov}(X_t, X_{t+h}), \qquad \rho(h) = \frac{\gamma(h)}{\gamma(0)} \tag{1.19}$$

جدول الرموز

الرمز	المعنى
μ	المتوسط الثابت
$\gamma(h)$	التغوّر الذاتي
$\rho(h)$	الارتباط الذاتي (ACF)
ϕ_{hh}	الارتباط الجزئي (PACF)

الرسم

<figure> الشكل<figcaption> 1.19: سلسلة ثابتة تراوح حول متوسط ثابت، و ACF تتضاءل مع



شكل ١٠١٩: *
الثبات ودالة الارتباط الذاتي

التأخّر.</figcaption> </figure>

البرهان (مخطّط)

الثبات الضعيف يفرض أن $\mathbb{E}[X_t]$ لا يعتمد على t، وأن $\mathrm{Cov}(X_t, X_{t+h})$ دالة في h فقط. منه $\rho(h) = \gamma(h)/\gamma(0)$ زوجية $|\rho(h)| \le 1$ (بكوشي–شفارتس من الفصل 5). ■

خمسة عشر مثالاً محلولاً

مثال (1-2.19): تمييز سلسلة ثابتة المعطيات: سلسلة تراوح حول 10 بتباين ثابت، وأخرى تصعد خطّياً. المطلوب: أيّهما ثابتة؟ الحل: الخطوة 1: الأولى $\mathbb{E}[X_t] = 10$ ثابت، الثانية $\mathbb{E}[X_t] = a + bt$ متغيّر. النتيجة: الأولى ثابتة، الثانية لا. الربط بالذكاء الاصطناعي: قبل تنبّؤ، تحقّق من ثبات سلسلة الطلب.

مثال (2-2.19): ACF للضوضاء البيضاء المعطيات: ε_t مستقلّة. المطلوب: $\rho(h)$. الحل: الخطوة 1: $\gamma(0) = \sigma^2$، $\gamma(h) = 0$ لـ $h \neq 0$. النتيجة: $\rho(h) = 0$ لكل $h \geq 1$. الربط بالذكاء الاصطناعي: بقايا نموذج جيد $\approx$ ضوضاء بيضاء.

مثال (3-2.19): ACF لـ AR(1) المعطيات: $X_t = \phi X_{t-1} + \varepsilon_t$، $|\phi| < 1$. المطلوب: $\rho(h)$. الحل: الخطوة 1: $\gamma(h) = \phi\gamma(h-1) \Rightarrow \gamma(h) = \phi^h\gamma(0)$. النتيجة: $\rho(h) = \phi^h$ (اضمحلال أسّي). الربط بالذكاء الاصطناعي: الاضمحلال الأسّي علامة AR.

مثال (19.2-4): اهتزاز ACF عند $\phi < 0$ المعطيات: $\phi = -0.7$. المطلوب: شكل ACF. الحل: الخطوة 1: $\rho(h) = (-0.7)^h$ تتناوب إشارة. النتيجة: اهتزاز متضائل. الربط بالذكاء الاصطناعي: سلوك مرتدّ (mean-reverting متذبذب).

مثال (19.2-5): تقدير ACF العيّني المعطيات: $x_1, \dots, x_n$، $\bar{x}$. المطلوب: $\hat{\rho}(h)$. الحل: الخطوة 1: $\hat{\gamma}(h) = \frac{1}{n}\sum_{t=1}^{n-h}(x_t - \bar{x})(x_{t+h} - \bar{x})$. الخطوة 2: $\hat{\rho}(h) = \hat{\gamma}(h)/\hat{\gamma}(0)$. النتيجة: مقدّر العيّنة. الربط بالذكاء الاصطناعي: تشخيص الارتباط الزمني في residuals.

مثال (19.2-6): ACF موسمي المعطيات: نمط يتكرّر كل 12 شهراً. المطلوب: علامة ACF. الحل: الخطوة 1: قمم عند $h = 12, 24, \dots$. النتيجة: دليل موسمية. الربط بالذكاء الاصطناعي: التنبّؤ بمبيعات موسمية.

مثال (19.2-7): PACF يقطع عند AR(p) المعطيات: AR(2). المطلوب: سلوك PACF. الحل: الخطوة 1: $\phi_{hh} = 0$ لـ $h > 2$. النتيجة: PACF يقطع عند التأخّر 2. الربط بالذكاء الاصطناعي: تحديد رتبة AR من PACF.

مثال (19.2-8): إزالة الاتجاه بالتفاضل المعطيات: سلسلة باتجاه خطّي. المطلوب: التحويل. الحل: الخطوة 1: $\nabla X_t = X_t - X_{t-1}$ يزيل الاتجاه. النتيجة: سلسلة ثابتة تقريباً. الربط بالذكاء الاصطناعي: preprocessing قبل التنبّؤ (stationarize).

مثال (19.2-9): تحويل لوغاريتمي لتثبيت التباين المعطيات: تباين ينمو مع المستوى. المطلوب: المعالجة. الحل: الخطوة 1: نأخذ $\log X_t$ فتصير النسبة هي المتغيّر. النتيجة: تباين مستقرّ. الربط بالذكاء الاصطناعي: تنبّؤ الطلب/الأسعار باللوغاريتم.

مثال (19.2-10): فحص المتوسط المتحرّك المعطيات: متوسط متحرّك 30 يوماً يصعد بثبات. المطلوب: الحكم. الحل: الخطوة 1: المتوسط غير ثابت $\Rightarrow$ السلسلة غير ثابتة. النتيجة: نحتاج تفاضلاً. الربط بالذكاء الاصطناعي: كشف انحراف في تدفّق البيانات (drfit).

مثال (19.2-11): اختبار لجونغ-بوكس المعطيات: نريد اختبار «لا ارتباط ذاتي» jointly. المطلوب: الإحصاء. الحل: الخطوة 1: $Q = n(n+2)\sum_{h=1}^{H}\frac{\hat{\rho}^2(h)}{n-h} \sim \chi^2_H$ تقريباً. النتيجة: رفض $\Rightarrow$ يوجد ارتباط. الربط بالذكاء الاصطناعي: فحص بقايا نموذج التنبّؤ.

مثال (19.2-12): ACF لـ MA(1) يقطع المعطيات: $X_t = \varepsilon_t + \theta\varepsilon_{t-1}$. المطلوب: $\rho(h)$. الحل: الخطوة 1: $\rho(1) = \frac{\theta}{1+\theta^2}$، $\rho(h) = 0$ لـ $h \geq 2$. النتيجة: قطع عند التأخّر 1. الربط بالذكاء الاصطناعي: التمييز بين AR و MA من ACF.

مثال (19.2-13): إزالة الاتجاه مقابل التفاضل المعطيات: اتجاه قطعي مقابل جذر وحدة. المطلوب: أيّهما؟ الحل: الخطوة 1: القطعي نطرح خطّاً، الجذر الوحدوي نُفاضل. النتيجة: اختبار ADF يفصل (انظر 19.5). الربط بالذكاء الاصطناعي: اختيار preprocessing صحيح.

مثال (19.2-14): مكوّن دوري المعطيات: دورة أعمال ~40 شهراً. المطلوب: أثر على ACF. الحل: الخطوة 1: تذبذب ACF ببطء (موجي). النتيجة: موجة في ACF. الربط بالذكاء الاصطناعي: التنبّؤ بدورات الحمل على الخوادم.

مثال (19.2-15): الثبات في تعلّم الآلة المعطيات: تدفّق بيانات يتغيّر توزيعه (drfit). المطلوب: العلاقة. الحل: الخطوة 1: drfit يعني فقدان الثبات $\Rightarrow$ النموذج يتدهور. النتيجة: نراقب الثبات لإعادة التدريب. الربط بالذكاء الاصطناعي: models monitoring في الإنتاج.

أخطاء شائعة

- الخلط بين الثبات الضعيف (لحظتان) والثبات التامّ (كل التوزيعات).
- قراءة ACF دون حساب فاصل الثقة $\pm 1.96/\sqrt{n}$.
- اعتبار أيّ اهتزاز في ACF دليلاً (قد يكون ضوضاء).

- نسيان أن التفاضل المفرط يضخّم الضوضاء.

نموذج (pAR):

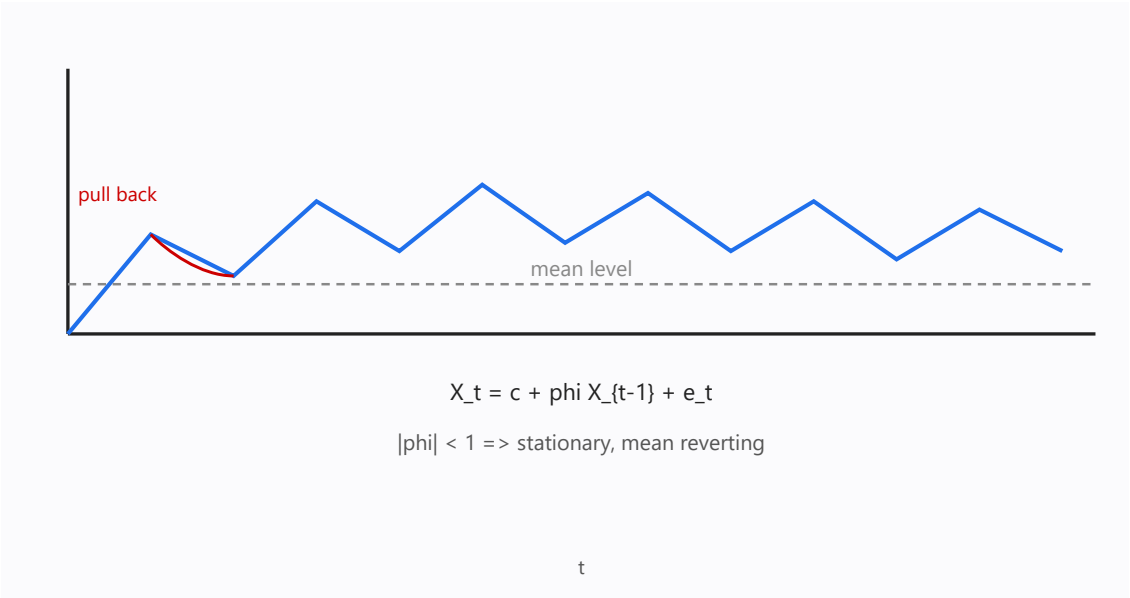
$$X_t = c + \sum_{i=1}^{p} \phi_i X_{t-i} + \varepsilon_t, \qquad \text{ffi ثابت AR}(1)|\phi_1| < 1 \tag{2.19}$$

جدول الرموز

الرمز	المعنى
ϕ_i	معاملات الانحدار الذاتي
c	الثابت
p	رتبة النموذج
ε_t	ضوضاء بيضاء

الرسم

<figure> الشكل<figcaption> 2.19: $\text{AR}(1)$ يعيد القيمة نحو المتوسط بمعامل ϕ؛ 1 $<$ $|\phi|$ يضمن



شكل ٢.١٩: *
نموذج الانحدار الذاتي AR

الثبات.</figure> <figcaption/>

البرهان (مخطّط)

بمؤثّر التأخّر: $(1-\phi L)X_t = c + \varepsilon_t$؛ الحلّ المقارب $X_t = \sum_{j\ge 0}\phi^j(c+\varepsilon_{t-j})$ يتقارب ffi $|\phi|<1$، فيكون المتوسط $c/(1-\phi)$ والتباين $\sigma^2/(1-\phi^2)$. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.19): محاكاة $\text{AR}(1)$ المعطيات: $\phi = 0.6$، $c = 0$، $\sigma = 1$. المطلوب: هل ثابت؟ الحل: الخطوة 1: $|\phi| = 0.6 < 1$. النتيجة: ثابت. الربط بالذكاء الاصطناعي: توليد سلسلة اصطناعية لاختبار نموذج.

مثال (19.3-2): متوسط AR(1) المعطيات: $c = 2$، $\phi = 0.5$. المطلوب: μ. الحل: الخطوة 1: $\mu = \mathbb{E}[X] = c/(1-\phi) \Rightarrow c + \phi\mu \Rightarrow \mu = 4$. الخطوة 2: $2/0.5 = 4$. النتيجة: $\mu = 4$. الربط بالذكاء الاصطناعي: مستوى توازن سلسلة (مثل حمل خادم).

مثال (19.3-3): تباين AR(1) المعطيات: $\sigma^2 = 1$، $\phi = 0.6$. المطلوب: $\mathrm{Var}(X_t)$. الحل: الخطوة 1: $\gamma(0) = \sigma^2/(1-\phi^2)$. الخطوة 2: $1/(1-0.36) = 1.5625$. النتيجة: $\mathrm{Var} = 1.5625$. الربط بالذكاء الاصطناعي: تذبذب أكبر من الضوضاء بسبب الذاكرة.

مثال (19.3-4): ACF لـ AR(1) المعطيات: $\phi = 0.6$. المطلوب: $\rho(3)$. الحل: الخطوة 1: $\rho(h) = \phi^h \Rightarrow 0.6^3 = 0.216$. النتيجة: $\rho(3) = 0.216$. الربط بالذكاء الاصطناعي: كم يؤثّر ماضٍ بعيد؟

مثال (19.3-5): تنبّؤ بخطوة واحدة المعطيات: $X_t = 10$، $\mu = 5$، $\phi = 0.8$. المطلوب: $\hat{X}_{t+1}$. الحل: الخطوة 1: $\hat{X}_{t+1} = \mu + \phi(X_t - \mu)$ بالصيغة المركزية. الخطوة 2: $5 + 0.8(10-5) = 9$. النتيجة: 9. الربط بالذكاء الاصطناعي: تنبّؤ الحمل اللحظي التالي.

مثال (19.3-6): تنبّؤ متعدّد الخطوات المعطيات: نفس ما سبق، نريد $\hat{X}_{t+3}$. المطلوب: التنبّؤ. الحل: الخطوة 1: $\hat{X}_{t+h} = \mu + \phi^h(X_t - \mu)$. الخطوة 2: $5 + 0.8^3 \times 5 = 5 + 2.56 = 7.56$. النتيجة: يقترب من μ مع البعد. الربط بالذكاء الاصطناعي: تنبّؤ بعيد المدى يعود للمتوسط.

مثال (19.3-7): شروط ثبات AR(2) المعطيات: $\phi_1 = 1.2$، $\phi_2 = -0.4$. المطلوب: الفحص. الحل: الخطوة 1: الشروط $\phi_1 + \phi_2 < 1$، $\phi_2 - \phi_1 < 1$، $|\phi_2| < 1$. الخطوة 2: $0.8 < 1$ ✓؛ $-1.6 < 1$ ✓؛ $0.4 < 1$ ✓. النتيجة: ثابت. الربط بالذكاء الاصطناعي: ضبط نموذج AR(2) لمتغيّر فيزيائي.

مثال (19.3-8): معادلات يول-ووكر المعطيات: $\rho(1) = 0.7$، $\rho(2) = 0.49$. المطلوب: ϕ_1, ϕ_2 لـ AR(2). الحل: الخطوة 1: حلّ النظام $\rho(h) = \phi_1\rho(h-1) + \phi_2\rho(h-2)$. الخطوة 2: من $h = 1, 2$: $\phi_1 \approx 0.7$، $\phi_2 \approx 0$. النتيجة: AR(1) كافٍ تقريباً. الربط بالذكاء الاصطناعي: تقدير معاملات من ACF وحدها.

مثال (19.3-9): عوائد الأسهم المعطيات: عوائد يومية. المطلوب: نمذجة AR؟ الحل: الخطوة 1: العوائد شبه ضوضاء، AR ضعيف. النتيجة: غالباً لا AR قوي (كفاءة السوق). الربط بالذكاء الاصطناعي: تحذير: لا نبالغ في AR للمالية.

مثال (19.3-10): درجة الحرارة المعطيات: حرارة يومية. المطلوب: هل AR مناسب؟ الحل: الخطوة 1: ارتباط قوي مع الأمس ($\phi \approx 0.85$). النتيجة: نعم، AR(1) جيد. الربط بالذكاء الاصطناعي: تنبّؤ حرارة/طاقة.

مثال (19.3-11): حركة الشبكة المعطيات: عدد الطلبات بالدقيقة. المطلوب: النمذجة. الحل: الخطوة 1: AR(1) – AR(3) مع دورة يومية. النتيجة: تنبّؤ الحمل. الربط بالذكاء الاصطناعي: autoscaling استباقي.

مثال (19.3-12): اختيار الرتبة (AIC) المعطيات: نقارن AR(1) و AR(3). المطلوب: المعيار. الحل: الخطوة 1: $AIC = -2\ell + 2k$؛ الأقلّ أفضل. النتيجة: اختيار موضوعي. الربط بالذكاء الاصطناعي: تجنّب الإفراط في رتبة النموذج.

مثال (19.3-13): جذر الوحدة المعطيات: $\phi = 1$ بالضبط. المطلوب: الثبات؟ الحل: الخطوة 1: $|\phi| = 1 \Rightarrow$ مشي عشوائي $\Rightarrow$ غير ثابت. النتيجة: نحتاج تفاضلاً (5.19). الربط بالذكاء الاصطناعي: كشف سلسلة غير قابلة للتنبّؤ المتوسطي.

مثال (19.3-14): AR مع انحدار (drfit) المعطيات: $c = 0.1$ في AR(1) بـ $\phi = 0.9$. المطلوب: المستوى الطويل. الحل: الخطوة 1: $\mu = c/(1-\phi) = 0.1/0.1 = 1$. النتيجة: توازن عند 1. الربط بالذكاء الاصطناعي: مستوى استقرار طويل الأمد.

مثال (19.3-15): AR والتوليد التراجعي المعطيات: نموذج يولّد الرمز التالي من السابق. المطلوب: العلاقة. الحل: الخطوة 1: نماذج اللغة التراجعية (GPT) = انحدار ذاتي على الرموز. النتيجة: AR تعميمي غير خطّي. الربط بالذكاء الاصطناعي: generation autoregressive في LLMs.

أخطاء شائعة

- تركيب AR على سلسلة غير ثابتة (نتائج زائفة).
- نسيان إعادةcentering عند التنبّؤ ($\mu + \phi(X_t - \mu)$).
- الخلط بين ϕ و $\rho(1)$ في AR(2)+ (متساويان في AR(1) فقط).
- تجاهل أن $|\phi| \geq 1$ يجعل التباين غير منتهٍ.

MA(q): $X_t = \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}$. والصيغة العامّة ARMA($p, q$) بمؤثّر التأخّر:

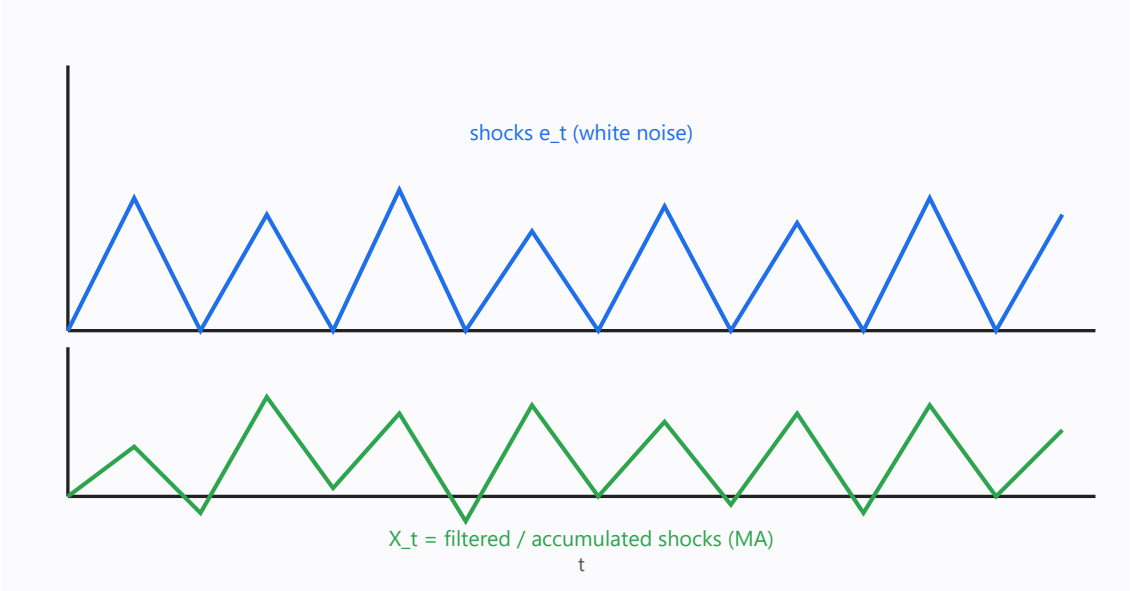
$$\Phi(L)\, X_t \;=\; \Theta(L)\, \varepsilon_t, \qquad \Phi(L) = 1 - \sum_{i=1}^{p} \phi_i L^i, \quad \Theta(L) = 1 + \sum_{j=1}^{q} \theta_j L^j \tag{3.19}$$

جدول الرموز

الرمز	المعنى
θ_j	معاملات المتوسط المتحرّك
L	مؤثّر التأخّر
Φ, Θ	كثيرات حدود AR و MA
$\lvert\theta\rvert < 1$	شرط الانعكاسيّة (MA(1))

الرسم

<figure> الشكل<figcaption> 3.19: MA يجمع صدمات ماضية؛ ARMA يجمع الانحدار الذاتي مع



شكل ٣.١٩: *
نماذج MA و ARMA

الصدمات.</figcaption> </figure>

البرهان (مخطّط)

)qMA) ثابت دائماً (مجموع منته من ضوضاء). الانعكاسيّة لـ MA(1) تشترط $|\theta| < 1$ لتمثيل X_t بدلالة ماضيه (تمثيل)∞AR)). ARMA ثابت ffi جذور $\Phi(z)$ خارج قرص الوحدة، وقابل للانعكاس ffi جذور $\Theta(z)$ خارجه. ■

خمسة عشر مثالاً محلولاً

مثال (19.4-1): تعريف MA(1) المعطيات: $X_t = \varepsilon_t + \theta\varepsilon_{t-1}$، $\theta = 0.5$. المطلوب: التباين. الحل: الخطوة 1: $\gamma(0) = \sigma^2(1+\theta^2) = 1.25\sigma^2$. النتيجة: التباين أكبر من الضوضاء. الربط بالذكاء الاصطناعي: تذبذب ناتج عن صدمة مستمرّة يومين.

مثال (19.4-2): ACF لـ MA(1) المعطيات: $\theta = 0.5$. المطلوب: $\rho(1), \rho(2)$. الحل: الخطوة 1: $\rho(1) = \theta/(1+\theta^2) = 0.5/1.25 = 0.4$. الخطوة 2: $\rho(h) = 0$ لـ $h \geq 2$. النتيجة: قطع عند 1. الربط بالذكاء الاصطناعي: ACF يقطع $\Rightarrow$ MA.

مثال (19.4-3): الانعكاسيّة المعطيات: $\theta = 1.5$. المطلوب: هل MA(1) قابل للانعكاس؟ الحل: الخطوة 1: $|\theta| = 1.5 > 1 \Rightarrow$ لا. النتيجة: نموذج مكافئ بـ $\theta = 1/1.5$ يفضّل. الربط بالذكاء الاصطناعي: of uniqueness representation.

مثال (19.4-4): ARMA$(1,1)$ المعطيات: $\phi = 0.6$، $\theta = 0.3$. المطلوب: الصيغة. الحل: الخطوة 1: $X_t = 0.6X_{t-1} + \varepsilon_t + 0.3\varepsilon_{t-1}$. النتيجة: يجمع الاثنين. الربط بالذكاء الاصطناعي: مرونة نمذجة أعلى برتبة منخفضة.

مثال (19.4-5): صيغة مؤثّر التأخّر المعطيات: ARMA$(1,1)$. المطلوب: $\Phi(L), \Theta(L)$. الحل: الخطوة 1: $\Phi(L) = 1 - 0.6L$، $\Theta(L) = 1 + 0.3L$. النتيجة: $(1-0.6L)X_t = (1+0.3L)\varepsilon_t$. الربط بالذكاء الاصطناعي: صيغة مدمجة للتنفيذ البرمجي.

مثال (19.4-6): السببيّة والانعكاسيّة معاً المعطيات: ARMA$(1,1)$ بـ $|\phi| < 1, |\theta| < 1$. المطلوب: الحالة. الحل: الخطوة 1: الجذور خارج قرص الوحدة للطرفين. النتيجة: نموذج ثابت وقابل للانعكاس. الربط بالذكاء الاصطناعي: ضمان تمثيل فريد ومستقرّ.

مثال (19.4-7): تنبّؤ ARMA$(1,1)$ المعطيات: $X_t = 10$، $\varepsilon_t = 0.5$. المطلوب: $\hat{X}_{t+1}$. الحل: الخطوة 1: $\hat{X}_{t+1} = \phi X_t + \theta\varepsilon_t = 0.6(10) + 0.3(0.5) = 6.15$. النتيجة: التنبّؤ. الربط بالذكاء الاصطناعي: التنبّؤ التكراري في خطوط الإنتاج.

مثال (19.4-8): دالة الاستجابة للصدمة (IRF) المعطيات: صدمة وحدة في ε_t. المطلوب: الأثر على X_{t+h}. الحل: الخطوة 1: يتضاءل حسب جذور Φ. النتيجة: أثر مؤقّت يزول. الربط بالذكاء الاصطناعي: تحليل حسّاسيّة تنبؤية.

مثال (19.4-9): نافذة تنعيم MA المعطيات: متوسط متحرّك بسيط على 7 أيام. المطلوب: العلاقة بـ MA. الحل: الخطوة 1: هو MA بمتوسط متساوٍ (غير قياسي). النتيجة: تنعيم = ترشيح تمرير منخفض. الربط بالذكاء الاصطناعي: smoothing قبل التنبّؤ.

مثال (19.4-10): تنبّؤ الطلب المعطيات: مبيعات يومية بموسمية أسبوعية. المطلوب: النموذج. الحل: الخطوة 1: ARMA مع مكوّن موسمي (SARMA). النتيجة: تنبّؤ دقيق. الربط بالذكاء الاصطناعي: إدارة المخزون.

مثال (19.4-11): تشخيص البقايا المعطيات: بعد الملاءمة نفحص residuals. المطلوب: المعيار. الحل: الخطوة 1: يجب أن تكون ضوضاء بيضاء (ACF ≈ 0). النتيجة: إن بقي ارتباط $\Rightarrow$ نرفع الرتبة. الربط بالذكاء الاصطناعي: model diagnostics قبل النشر.

مثال (19.4-12): التقتير (parsimony) المعطيات: ARMA$(1,1)$ مقابل AR(5). المطلوب: أيهما أفضل؟ الحل: الخطوة 1: ARMA$(1,1)$ بمعاملين يكافئ ذاكرة أطول. النتيجة: أقلّ معاملات $\Rightarrow$ أفضل تعميم. الربط بالذكاء الاصطناعي: مبدأ الأبسط/MDL أفضل.

مثال (19.4-13): AIC/BIC للاختيار المعطيات: عدّة مرشّحات. المطلوب: القاعدة. الحل: الخطوة 1: AIC يميل

للمرونة؛ BIC يعاقب أقسى $(k \ln n)$. النتيجة: BIC أكثر تحفّظاً. الربط بالذكاء الاصطناعي: اختيار نموذج تلقائي.

مثال (14-4.19): كشف الشذوذ المعطيات: ARMA يتبنّأ؛ نقطة بعيدة جدّاً. المطلوب: الكشف. الحل: الخطوة 1: الباقي $|x_t - \hat{x}_t| > 3\hat{\sigma} \Rightarrow$ شذوذ. النتيجة: إنذار. الربط بالذكاء الاصطناعي: detection anomaly على السلاسل.

مثال (15-4.19): ARMA كمرشّح خطّي المعطيات: النظام $\Phi(L)X = \Theta(L)\varepsilon$. المطلوب: التفسير الهندسي. الحل: الخطوة 1: مرشّح خطّي يحوّل ضوضاء بيضاء لسلسلة ملوّنة. النتيجة: ربط بمعالجة الإشارة. الربط بالذكاء الاصطناعي: مرشّحات/CNN على إشارات زمنية.

أخطاء شائعة

- الخلط بين MA كنموذج إحصائي والمتوسط المتحرّك البسيط في التنعيم.
- نسيان أن MA ثابت دائماً (لا شرط ثبات، بل شرط انعكاس).
- تجاهل الانعكاسيّة فتظهر تمثيلات مكافئة مربكة.
- المبالغة في الرتبة فيصير التقدير غير مستقرّ.

المشي العشوائي $X_t = X_{t-1} + \varepsilon_t$ غير ثابت $(\mathrm{Var} = t\sigma^2)$؛ بالتفاضل d مرّة نصير ثابتين، فنحصل على $\mathrm{ARIMA}(p,d,q)$:

$$\Phi(L)\,(1-L)^d X_t = \Theta(L)\,\varepsilon_t, \qquad \nabla^d = (1-L)^d \tag{4.19}$$

جدول الرموز

الرمز	المعنى
d	رتبة التفاضل
∇	مؤثّر الفرق $1-L$
H_0:	جذر وحدة اختبار ADF

الرسم

<figure> الشكل<figcaption> 4.19: المشي العشوائي يتشعّب بتباين ينمو مع t؛ التفاضل يعيده ضوضاء.</figcaption>
</figure>

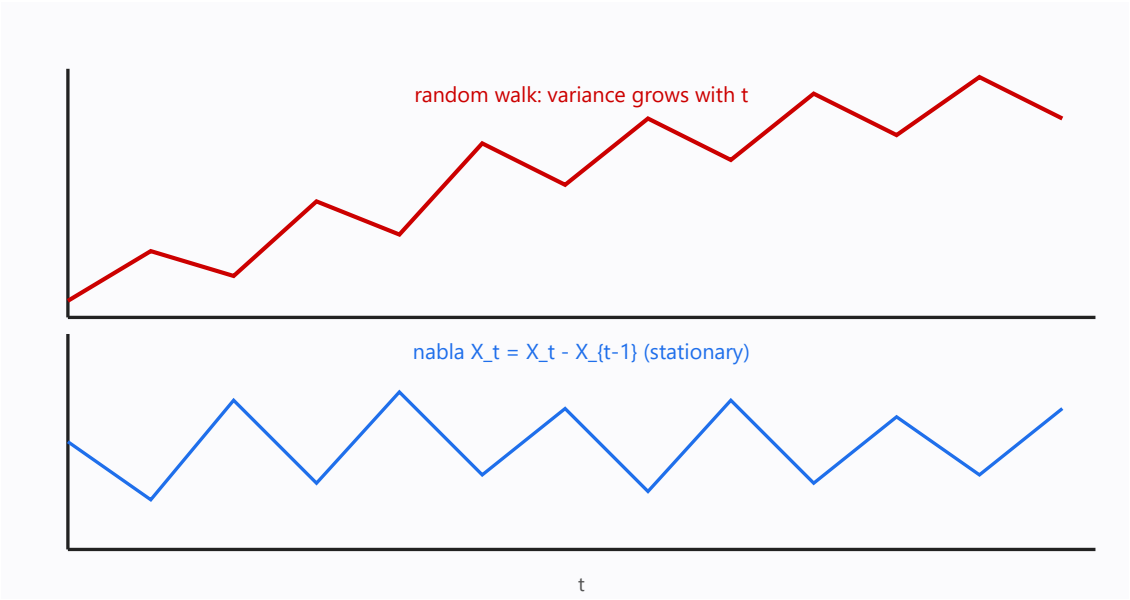
البرهان (مخطّط)

$\mathrm{Var}(X_t) = t\sigma^2 \to \infty \Rightarrow X_t = X_0 + \sum_{s \le t} \varepsilon_s$ فغير ثابت. لكن $\nabla X_t = \varepsilon_t$ ضوضاء بيضاء $\Rightarrow$ ثابت. بتطبيق ∇^d ثمّ ARMA نحصل على (4.19). ■

خمسة عشر مثالاً محلولاً

مثال (1-5.19): تعريف المشي العشوائي المعطيات: $X_0 = 0$، $\sigma^2 = 1$. المطلوب: $\mathbb{E}[X_t], \mathrm{Var}(X_t)$. الحل: الخطوة 1: $\mathbb{E} = 0$؛ $\mathrm{Var} = t$. النتيجة: التباين ينمو خطّياً. الربط بالذكاء الاصطناعي: مسار أسعار غير متوقّع.

مثال (2-5.19): نمو التباين المعطيات: $t = 100$. المطلوب: الانحراف المعياري. الحل: الخطوة 1: $\sqrt{100 \times 1} = 10$. النتيجة: انتشار واسع. الربط بالذكاء الاصطناعي: ثقة التنبّؤ تتضاءل مع الأفق.



شكل ١٩.٤٠: *
المشي العشوائي التفاضل وARIMA

مثال (19.5-3): عدم الثبات المعطيات: مشي عشوائي. المطلوب: هل AR(1) بـ $\phi = 1$ ثابت؟ الحل: الخطوة 1: لا، $|\phi| = 1 \Rightarrow$ جذر وحدة. النتيجة: غير ثابت. الربط بالذكاء الاصطناعي: لا نتنبّأ بمستوى ثابت.

مثال (19.5-4): التفاضل يعيد الضوضاء المعطيات: مشي عشوائي. المطلوب: ∇X_t. الحل: الخطوة 1: $X_t - X_{t-1} = \varepsilon_t$. النتيجة: ضوضاء بيضاء $\Rightarrow$ ثابت. الربط بالذكاء الاصطناعي: preprocessing للتنبّؤ.

مثال (19.5-5): ARIMA(0,1,0) المعطيات: $d = 1$ بلا AR/MA. المطلوب: ما هو؟ الحل: الخطوة 1: هو المشي العشوائي نفسه. النتيجة: التنبّؤ = آخر قيمة. الربط بالذكاء الاصطناعي: forecast naive baseline.

مثال (19.5-6): ARIMA(1,1,1) المعطيات: الصيغة العامّة. المطلوب: اكتبها. الحل: الخطوة 1: $\Phi(L)(1-L)X_t = \Theta(L)\varepsilon_t$. النتيجة: ARMA على السلسلة المفاضلة. الربط بالذكاء الاصطناعي: نموذج تنبّؤ صناعي شائع.

مثال (19.5-7): اختبار الجذر الوحدوي (ADF) المعطيات: نختبر $\rho = 1$ في $\nabla X_t = (\rho - 1)X_{t-1} + \dots$. المطلوب: القاعدة. الحل: الخطوة 1: إحصاء t غير قياسي (توزيع ديكي–فولر)؛ الرفض $\Rightarrow$ ثابت. النتيجة: قرار d. الربط بالذكاء الاصطناعي: أتمتة اختيار d.

مثال (19.5-8): مشي عشوائي بانحدار المعطيات: $X_t = \delta + X_{t-1} + \varepsilon_t$، $\delta = 0.05$. المطلوب: الاتجاه. الحل: الخطوة 1: $\mathbb{E}[X_t] = 0.05t$ صاعد. النتيجة: اتجاه تراكمي. الربط بالذكاء الاصطناعي: نموّ طويل الأمد في الطلب.

مثال (19.5-9): تنبّؤ المشي العشوائي المعطيات: $X_t = 50$. المطلوب: $\hat{X}_{t+h}$. الحل: الخطوة 1: أفضل تنبؤ $= 50$ لكل h. الخطوة 2: لكن فاصل الثقة ينمو $\propto \sqrt{h}$. النتيجة: تنبؤ نقطي ثابت، يقين متضائل. الربط بالذكاء الاصطناعي: حدود التنبّؤ بعيد المدى.

مثال (19.5-10): أسعار الأسهم المعطيات: السعر P_t. المطلوب: النمذجة. الحل: الخطوة 1: $\log P_t \approx$ مشي عشوائي؛ العوائد $\approx$ ضوضاء. النتيجة: التنبّؤ بالاتجاه مستحيل (كفاءة). الربط بالذكاء الاصطناعي: RL للتداول يركّز على المخاطر لا التنبّؤ.

مثال (19.5-11): تنبّؤ المبيعات المعطيات: مبيعات شهرية باتجاه وموسمية. المطلوب: النموذج. الحل: الخطوة 1: ARIMA مع مكوّن موسمي (SARIMA). النتيجة: تنبّؤ تشغيلي. الربط بالذكاء الاصطناعي: تخطيط سلسلة التوريد.

مثال (19.5-12): خطر التفاضل المفرط المعطيات: نُفاضل سلسلة ثابتة أصلاً. المطلوب: الأثر. الحل: الخطوة 1:

نُدخل ارتباطاً سالباً مصطنعاً ونضخّم الضوضاء. النتيجة: تنبّؤ أسوأ. الربط بالذكاء الاصطناعي: لا تُفاضل قبل اختبار ADF.

مثال (19.5-13): SARIMA المعطيات: موسمية 12. المطلوب: الصيغة. الحل: الخطوة 1: ARIMA$\times$ $(p,d,q)\times(P,D,Q)_{12}$. النتيجة: نموذج بموسمية. الربط بالذكاء الاصطناعي: التنبّؤ الموسمي في التجزئة.

مثال (19.5-14): حمل الخادم المعطيات: حمل بالدقيقة باتجاه تصاعدي. المطلوب: المعالجة. الحل: الخطوة 1: نُفاضل ثمّ ARMA. النتيجة: تنبّؤ autoscaling. الربط بالذكاء الاصطناعي: إدارة موارد سحابية.

مثال (19.5-15): التكامل المشترك (cointegration) المعطيات: سلسلتان غير ثابتتين تتحرّكان معاً. المطلوب: الفكرة. الحل: الخطوة 1: مزيجهما الخطّي ثابت $\Rightarrow$ علاقة توازن طويلة. النتيجة: pairs trading. الربط بالذكاء الاصطناعي: استراتيجيات تداول إحصائية.

أخطاء شائعة

- تفاضل سلسلة ثابتة (over-dffierencing).
- استخدام إحصاء t العادي في ADF (توزيع خاصّ).
- الظن أن المشي العشوائي «يتنبّأ بالاتجاه» — تنبؤه ثابت عند آخر قيمة.
- نسيان أن فاصل الثقة ينمو $\sqrt{h}$ فينهار اليقين بعيداً.

عملية عدّ $N(t)$ بمعدّل λ (متجانسة): مستقلّة الزيادات، و

$$\mathbb{P}\big(N(t+h)-N(t)=1\big)=\lambda h+o(h),\qquad N(t)\sim\text{Poisson}(\lambda t) \tag{5.19}$$

جدول الرموز

الرمز	المعنى
$N(t)$	عدد الأحداث حتى t
λ	المعدّل (أحداث/وحدة زمن)
T_i	زمن الحدث i
S_i	فاصل الوصول (inter-arrival)

الرسم

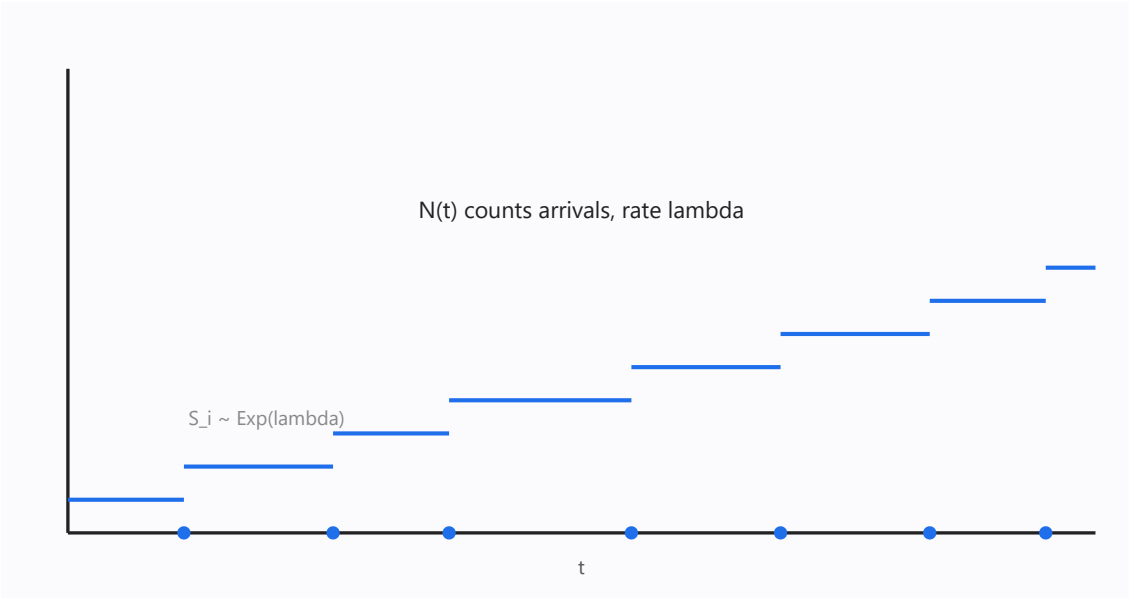
<figure> الشكل<figcaption> 5.19: فواصل الوصول أسّية؛ العدّ في نافذة ثابتة يتبع بواسون.</figcaption>
</figure>

البرهان (مخطّط)

من استقلال الزيادات وشرط المعدّل، $N(t+s)-N(t)\sim\text{Poisson}(\lambda s)$ عبر معادلة كولموغروف الأمامية؛ ومنه $S_i=T_i-T_{i-1}\sim\text{Exp}(\lambda)$ مستقلّة (ذاكرة معدومة). ■

خمسة عشر مثالاً محلولاً

مثال (19.6-1): تعريف العدّ المعطيات: $\lambda=5$/دقيقة. المطلوب: $\mathbb{E}[N(10)]$. الحل: الخطوة 1: $\lambda t=50$. النتيجة: 50 حدثاً متوقّعاً. الربط بالذكاء الاصطناعي: تخطيط سعة خدمة استدلال.



شكل ٥.١٩: *
عملية بواسون: وصول أحداث بمعدل لامدا

مثال (2-6.19): احتمال عدد محدّد المعطيات: $\lambda = 2$، $t = 3$. المطلوب: $\mathbb{P}(N = 4)$. الحل: الخطوة 1: $e^{-6}6^4/4! \approx 0.1339$. النتيجة: ≈13.4٪. الربط بالذكاء الاصطناعي: احتمال تجاوز طوابير.

مثال (3-6.19): فواصل الوصول المعطيات: $\lambda = 0.5$/ساعة. المطلوب: توزيع الفاصل. الحل: الخطوة 1: $S \sim \text{Exp}(0.5) \Rightarrow$ متوسط 2 ساعة. النتيجة: فواصل أسّية. الربط بالذكاء الاصطناعي: نمذجة زمن بين الأعطال.

مثال (4-6.19): خاصّية الذاكرة المعدومة المعطيات: مرّت ساعة بلا حدث. المطلوب: احتمال حدث في الساعة التالية؟ الحل: الخطوة 1: $\mathbb{P}(S > 2 \mid S > 1) = \mathbb{P}(S > 1) = e^{-0.5} \approx 0.607$. النتيجة: الماضي لا يؤثّر. الربط بالذكاء الاصطناعي: why memoryless exponential matters.

مثال (5-6.19): تراكب عمليتين المعطيات: $\lambda_1 = 3$، $\lambda_2 = 4$ مستقلّتان. المطلوب: المجموع. الحل: الخطوة 1: بواسون بمعدّل 7. النتيجة: تراكب يحفظ بواسون. الربط بالذكاء الاصطناعي: دمج تدفّقات أحداث من خدمات.

مثال (6-6.19): التقسيم (thinning) المعطيات: نسبة 20٪ من الأحداث «حرجة». المطلوب: توزيع الحرجة. الحل: الخطوة 1: بواسون بمعدّل 0.2λ. النتيجة: تقسيم مستقلّ. الربط بالذكاء الاصطناعي: توجيه أنواع التنبيهات.

مثال (7-6.19): بواسون غير متجانسة المعطيات: $\lambda(t)$ متغيّرة (ذروة نهارية). المطلوب: العدّ. الحل: الخطوة 1: $N(t) \sim \text{Poisson}(\int_0^t \lambda(u)du)$. النتيجة: معدّل تراكمي. الربط بالذكاء الاصطناعي: نمذجة حمل متغيّر يومياً.

مثال (8-6.19): وصول الطلبات المعطيات: 600 طلب/ساعة. المطلوب: احتمال >12 في دقيقة. الحل: الخطوة 1: $\lambda = 10$/دقيقة؛ نحسب ذيل بواسون. النتيجة: تخطيط الطاقة الاستيعابية. الربط بالذكاء الاصطناعي: autoscaling بناءً على بواسون.

مثال (9-6.19): أحداث الفشل المعطيات: 2 عطل/شهر. المطلوب: احتمال صفر في شهر. الحل: الخطوة 1: $e^{-2} \approx 0.135$. النتيجة: ≈13.5٪. الربط بالذكاء الاصطناعي: موثوقية العُقد.

مثال (10-6.19): بواسون مركّبة المعطيات: كل حدث بحجم عشوائي Y. المطلوب: المجموع الكلّي. الحل: الخطوة 1: $Z = \sum_{i=1}^{N(t)} Y_i$، تباينه $\lambda t\, \mathbb{E}[Y^2]$. النتيجة: نموذج حجم تراكمي. الربط بالذكاء الاصطناعي: حجم بيانات مجمّعة من أحداث.

مثال (11-6.19): طوابير (M/M/1) المعطيات: وصول بواسون، خدمة أسّية. المطلوب: شرط الاستقرار. الحل: الخطوة 1: $\rho = \lambda/\mu < 1$. النتيجة: دون ذلك ينفجر الطابور. الربط بالذكاء الاصطناعي: تصميم خوادم الاستدلال.

مثال (19.6-12): تقدير λ المعطيات: 120 حدثاً في 30 دقيقة. المطلوب: $\hat\lambda$. الحل: الخطوة 1: $= 120/30$ دقيقة/4 (MLE من 18.2). النتيجة: التقدير. الربط بالذكاء الاصطناعي: ضبط نموذج الحمل.

مثال (19.6-13): بواسون كنهاية لذات الحدّين المعطيات: n كبير، p صغير، $np = \lambda$. المطلوب: التقارب. الحل: الخطوة 1: $\text{Bin}(n,p) \to \text{Poisson}(\lambda)$. النتيجة: تقريب الأحداث النادرة. الربط بالذكاء الاصطناعي: نمذجة هجمات نادرة.

مثال (19.6-14): تقريب الحدث النادر المعطيات: احتمال فشل 0.001 لكل 1000 طلب. المطلوب: عدد الفشل. الحل: الخطوة 1: $\lambda = 1 \Rightarrow$ بواسون(1). النتيجة: سهولة الحساب. الربط بالذكاء الاصطناعي: تنبيهات الجودة.

مثال (19.6-15): التنبّؤ بالأحداث المعطيات: نريد احتمال ≥ 1 حدث في 5 دقائق. المطلوب: الحساب بـ $\lambda = 0.4$/دقيقة. الحل: الخطوة 1: $1 - e^{-2} \approx 0.865$. النتيجة: $\approx 86.5\%$. الربط بالذكاء الاصطناعي: إنذار استباقي.

أخطاء شائعة

- افتراض بواسون عند وجود تجمّع (over-dispersion).
- نسيان أن فواصل الوصول أسّية وليست منتظمة.
- الخلط بين المعدّل λ والتباين (متساويان في بواسون).
- تجاهل عدم التجانس الزمني في الحمل الفعلي.

عملية وينر W_t: $W_0 = 0$، مسارات متّصلة، زيادات مستقلّة، و

$$W_t - W_s \sim \mathcal{N}(0,\, t-s), \qquad dX_t = \mu(X_t,t)\,dt + \sigma(X_t,t)\,dW_t \tag{6.19}$$

جدول الرموز

الرمز	المعنى
W_t	عملية وينر (الحركة البراونية)
μ	الانحدار (drfit)
σ	الانتشار (dffiusion)
dW_t	زيادة وينر اللامتنهية

الرسم

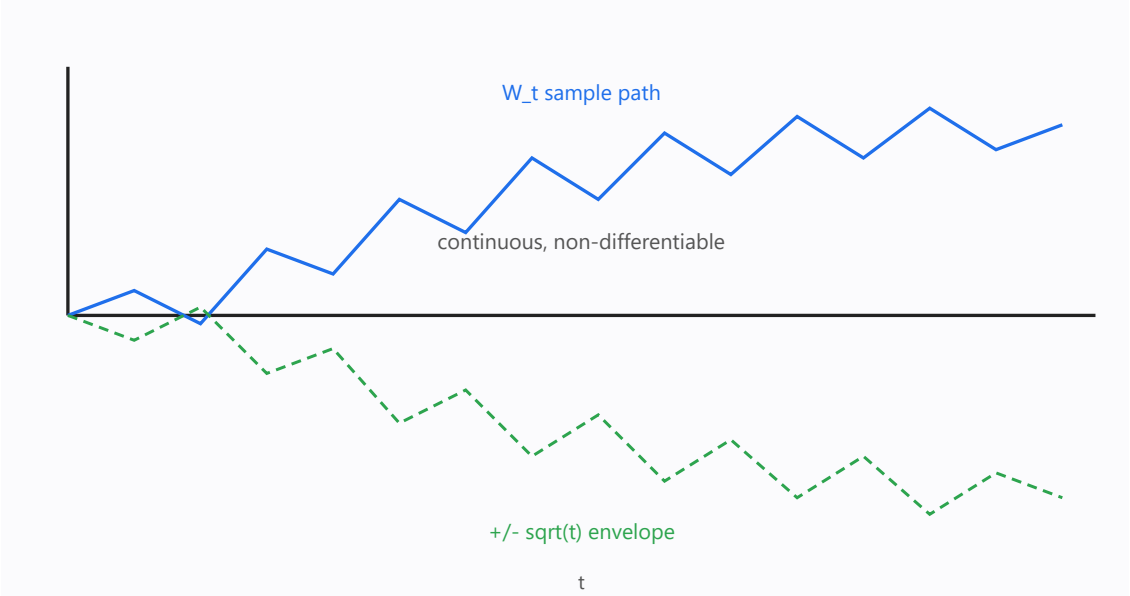
<figure> الشكل<figcaption> 6.19: مسارات وينر متّصلة غير قابلة للاشتقاق، بتباين ينمو خطّياً مع الزمن.</figcaption> </figure>

البرهان (مخطّط)

الحركة البراونية هي نهاية مقيسة للمشي العشوائي (principle): invariance بتقليص الخطوة $\Delta t \to 0$ و$\Delta x \to 0$ بـ $(\Delta x)^2/\Delta t = \sigma^2$ نحصل على W_t. معادلة (6.19) تُقرأ تكاملياً: $X_t = X_0 + \int \mu\,dt + \int \sigma\,dW$ (تكامل Itô من الفصل 10/12). ■

خمسة عشر مثالاً محلولاً

مثال (19.7-1): خصائص وينر المعطيات: W_t. المطلوب: $\mathbb{E}[W_t], \text{Var}(W_t)$. الحل: الخطوة 1: 0 و t. النتيجة: التباين ينمو خطّياً. الربط بالذكاء الاصطناعي: أساس الضوضاء في النماذج التوليدية.



شكل ٦.١٩: *
الحركة البراونية ومسارات وينر

مثال (2-7.19): استقلال الزيادات المعطيات: $W_t - W_s$ و $W_s - W_0$. المطلوب: العلاقة. الحل: الخطوة 1: مستقلّتان (زيادات متقاطعة). النتيجة: مارتنغيال (8.19). الربط بالذكاء الاصطناعي: توليد مسارات تدريجياً.

مثال (3-7.19): توزيع W_t المعطيات: $t = 4$. المطلوب: التوزيع. الحل: الخطوة 1: $\mathcal{N}(0, 4) \Rightarrow$ انحراف 2. النتيجة: انتشار $\sqrt{t}$. الربط بالذكاء الاصطناعي: جدولة الضوضاء في dffiusion.

مثال (4-7.19): التشابه الذاتي المعطيات: W_{ct} مقابل $\sqrt{c}W_t$. المطلوب: العلاقة. الحل: الخطوة 1: متساويان توزيعاً. (sefl-similar) النتيجة: خاصّية قياسيّة. الربط بالذكاء الاصطناعي: توليد بمقاييس زمنية.

مثال (5-7.19): جسر براوني المعطيات: نثبّت $W_T = 0$. المطلوب: التوزيع. الحل: الخطوة 1: $B_t = W_t - \frac{t}{T}W_T \Rightarrow$ غاوسي مشروط. النتيجة: جسر. الربط بالذكاء الاصطناعي: توليد مشروط بالنهاية.

مثال (6-7.19): الحركة البراونية الهندسية (GBM) المعطيات: $dS = \mu S dt + \sigma S dW$. المطلوب: الحلّ. الحل: الخطوة 1: $S_t = S_0 e^{(\mu - \sigma^2/2)t + \sigma W_t}$. النتيجة: لوغاريتم طبيعي. الربط بالذكاء الاصطناعي: تسعير الأصول/المخاطر.

مثال (7-7.19): GBM ولوغاريتم طبيعي المعطيات: $\mu = 0.1$، $\sigma = 0.2$، $t = 1$، $S_0 = 100$. المطلوب: الوسيط المتوقّع. الحل: الخطوة 1: الوسيط $= S_0 e^{(\mu - \sigma^2/2)} = 100 e^{0.08} \approx 108.3$. النتيجة: الوسيط أقلّ من المتوسط. الربط بالذكاء الاصطناعي: الفرق بين المتوسط والوسيط مهمّ.

مثال (8-7.19): لمّة إيتو المعطيات: $f(W_t) = W_t^2$. المطلوب: التفاضل. الحل: الخطوة 1: $df = 2W_t dW_t + dt$ (حدّ إيتو $+dt$). النتيجة: تصحيح درجة ثانية. الربط بالذكاء الاصطناعي: ضروري لاشتقاق score/SDE.

مثال (9-7.19): أورنشتاين–أولنبك (OU) المعطيات: $dX = \theta(\mu - X)dt + \sigma dW$. المطلوب: السلوك. الحل: الخطوة 1: ارتداد نحو μ مع ضوضاء. النتيجة: عملية ثابتة مستمرّة. الربط بالذكاء الاصطناعي: mean-reversion في RL/المالية.

مثال (10-7.19): OU كـ AR(1) مستمرّ المعطيات: تشبيه منفصل. المطلوب: التماثل. الحل: الخطوة 1: $X_{t+\Delta} \approx X_t + \theta(\mu - X_t)\Delta + \sigma\sqrt{\Delta}\,\varepsilon$. النتيجة: AR(1) بـ $\phi = 1 - \theta\Delta$. الربط بالذكاء الاصطناعي: وصل منفصل/متّصل.

مثال (11-7.19): صيغة SDE عامّة المعطيات: $dX = \mu dt + \sigma dW$. المطلوب: التفسير. الحل: الخطوة 1: drfit حتمي + انتشار عشوائي. النتيجة: إطار موحّد. الربط بالذكاء الاصطناعي: Neural SDE/dffiusion.

مثال (19.7-12): أويلر–مارورياما المعطيات: نريد محاكاة. المطلوب: المخطّط. الحل: الخطوة 1: $X_{n+1} = X_n + \mu\Delta t + \sigma\sqrt{\Delta t}\,Z$. النتيجة: محاكاة عددية (انظر 3.12). الربط بالذكاء الاصطناعي: أخذ عيّنات من نماذج الانتشار.

مثال (19.7-13): زمن العبور الأول المعطيات: متى يصعد W_t فوق a؟ المطلوب: التوزيع. الحل: الخطوة 1: قانون ليفي (أو انعكاس) $\Rightarrow$ كثافة معروفة. النتيجة: توقّع متوسط لانهائي لـ W (لكن العبور شبه مؤكّد). الربط بالذكاء الاصطناعي: أزمنة التوقّف في المراقبة.

مثال (19.7-14): البراونية في نماذج الانتشار المعطيات: VP-SDE من الفصل 12. المطلوب: العلاقة. الحل: الخطوة 1: الانتشار الأمامي SDE بقيادة W_t؛ العكسي بقيادة $\nabla \log p_t$. النتيجة: البراونية هي العمود الفقري. الربط بالذكاء الاصطناعي: models dffiusion التوليدية.

مثال (19.7-15): GBM في التعلّم المعزّز المعطيات: بيئة مالية بـ GBM. المطلوب: النمذجة. الحل: الخطوة 1: الحالة تتطوّر بـ SDE؛ الوكيل يتعلّم السياسة. النتيجة: MDP مستمرّ. الربط بالذكاء الاصطناعي: RL في الأسواق المالية.

أخطاء شائعة

- معاملة dW كتفاضل عادي ($dW \sim \sqrt{dt}$ لا dt).
- نسيان حدّ إيتو $(dW)^2 = dt$.
- الخلط بين W_t و X_t (الحلّ مقابل الضوضاء).
- الظن أن مسارات وينر قابلة للاشتقاق (غير قابلة أينما كان).

عملية M_t مكيّفة مع $\mathcal{F}_t$ تُسمّى **مارتنغيال** إذا:

$$\mathbb{E}\big[M_{t+1} \mid \mathcal{F}_t\big] = M_t, \qquad \text{وبشرط صحّة:} \quad \mathbb{E}[M_\tau] = \mathbb{E}[M_0] \tag{7.19}$$

لأيّ زمن توقّف τ محدود (مبرهنة التوقّف الاختياري).

جدول الرموز

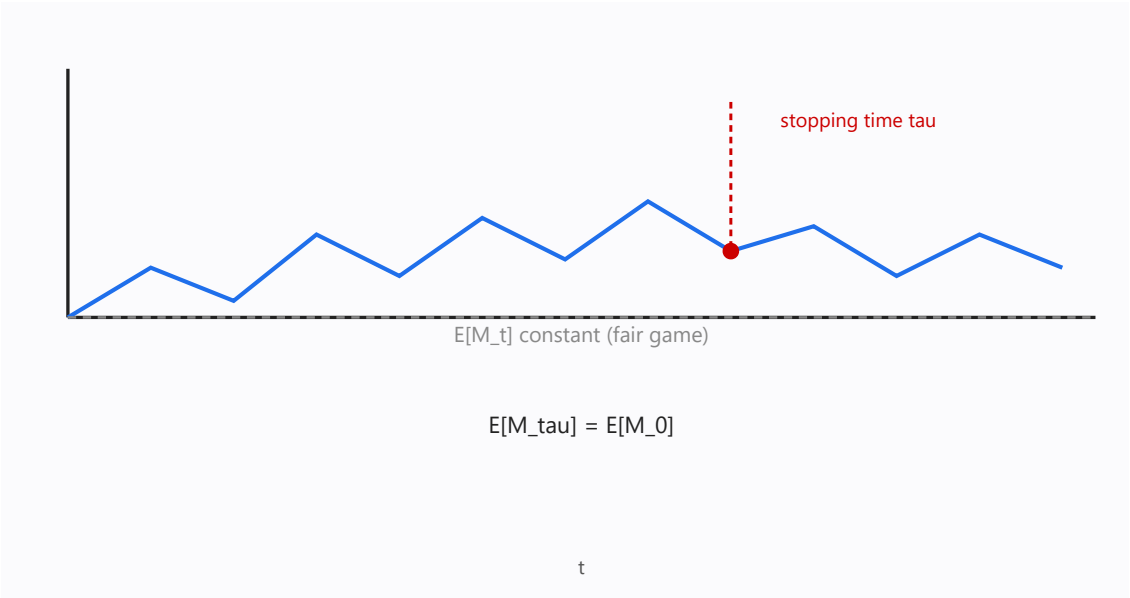
الرمز	المعنى
$\mathcal{F}_t$	الترشيح (المعلومات المتاحة)
M_t	المارتنغيال
τ	زمن التوقّف
M_t^-/M_t^+	مارتنغيال فرعي/أدنى

الرسم

<figure> الشكل 7.19: اللعب العادل — التوقّع المشروط للقيمة التالية هو القيمة الحالية؛ التوقّف لا يغيّر المتوقّع. </figure>

البرهان (مخطّط)

للتوقّف الاختياري، نكتب $M_{t\wedge\tau}$ مارتنغيالاً موقوفاً (مبرهنة التوقّف الموقوف)، ثمّ نمرّر الحدّ بـ DCT (من الفصل 10) لنحصل على $\mathbb{E}[M_\tau] = \mathbb{E}[M_0]$ بشروط صحّة (محدوديّة أو تكامل موحّد). ■



شكل ٧.١٩: *
المارتنغيال والتوقف الاختياري

خمسة عشر مثالاً محلولاً

مثال (1-8.19): تعريف المارتنغيال المعطيات: $M_{t+1} = M_t + \varepsilon_{t+1}$، $\mathbb{E}[\varepsilon] = 0$. المطلوب: هل مارتنغيال؟ الحل: الخطوة 1: $\mathbb{E}[M_{t+1} \mid \mathcal{F}_t] = M_t$. النتيجة: نعم. الربط بالذكاء الاصطناعي: تحديثات ذات متوسط صفري.

مثال (2-8.19): اللعب العادل المعطيات: رهان عادل مرّة بعد مرّة. المطلوب: توقّع الثروة. الحل: الخطوة 1: الثروة مارتنغيال؛ المتوقّع ثابت. النتيجة: لا ربح متوقّع بالتكرار وحده. الربط بالذكاء الاصطناعي: لا «نظام رهان» يربح بالمتوسط.

مثال (3-8.19): المشي العشوائي مارتنغيال المعطيات: $X_t = X_{t-1} + \varepsilon_t$، $\mathbb{E}[\varepsilon] = 0$. المطلوب: البرهان. الحل: الخطوة 1: $\mathbb{E}[X_{t+1} \mid \mathcal{F}_t] = X_t$. النتيجة: نعم. الربط بالذكاء الاصطناعي: تراكم التدرّجات الصفريّة المتوسطة.

مثال (4-8.19): التوقّف الاختياري المعطيات: نتوقّف عند τ (مثلاً أول ربح 10). المطلوب: المتوقّع عند التوقّف. الحل: الخطوة 1: بشروط صحّة $\mathbb{E}[M_\tau] = \mathbb{E}[M_0]$. النتيجة: التوقّف لا يخلق قيمة. الربط بالذكاء الاصطناعي: لا توقّف ذكي يربح بلعبة عادلة.

مثال (5-8.19): إفلاس المقامر المعطيات: رأس مال i، هدف N، رهان عادل. المطلوب: احتمال الوصول للهدف. الحل: الخطوة 1: بالمارتنغيال X_t الثروة: $\mathbb{E}[X_\tau] = i \Rightarrow P(\text{win}) = i/N$. النتيجة: الاحتمال يتناسب مع رأس المال. الربط بالذكاء الاصطناعي: احتمال النجاح في عملية تصادفيّة بهدف.

مثال (6-8.19): تقارب دوب المعطيات: $M_t \geq 0$ مارتنغيال. المطلوب: التقارب. الحل: الخطوة 1: يتقارب شبه مؤكّد إلى M_∞ منته. النتيجة: ضمان تقارب. الربط بالذكاء الاصطناعي: تقارب خوارزميات تكرارية بمتوسط صفري.

مثال (7-8.19): وصلة أزوما من 7.17 المعطيات: مارتنغيال بفروق مقيدة c_k. المطلوب: القيد. الحل: الخطوة 1: $2\exp(-t^2/2\sum c_k^2)$. النتيجة: مترابحة التركيز للمسيرات. الربط بالذكاء الاصطناعي: حدود تعميم الاستقرار.

مثال (8-8.19): مارتنغيال فرعي المعطيات: $M_t \geq \mathbb{E}[M_{t+1} \mid \mathcal{F}_t]$. المطلوب: التسمية. الحل: الخطوة 1: مارتنغيال فرعي (submartingale) — يميل للصعود. النتيجة: ($\leq$) $\Rightarrow$ أدنى. (super) الربط بالذكاء الاصطناعي: خسارة تنقص $\Rightarrow$ supermartingale.

مثال (9-8.19): نسبة الاحتمال مارتنغيال المعطيات: $L_t = p_1(X_{1..t})/p_0(X_{1..t})$ تحت H_0. المطلوب: الخاصّية. الحل: الخطوة 1: $\mathbb{E}_0[L_{t+1} \mid \mathcal{F}_t] = L_t$. النتيجة: مارتنغيال تحت الفرضية الصفرية. الربط بالذكاء الاصطناعي: الاختبارات التتابعية (sequential testing).

مثال (19.8-10): نظام الرهان المضاعف المعطيات: نضاعف الرهان بعد كلّ خسارة. المطلوب: هل يربح؟ الحل: الخطوة 1: المتوقّع يبقى 0 (مارتنغيال) لكن التباين ينفجر. النتيجة: مخاطرة إفلاس بلا ربح متوقّع. الربط بالذكاء الاصطناعي: تحذير من «استراتيجيات» مشابهة في التداول الآلي.

مثال (19.8-11): SGD كمارتنغيال المعطيات: تحديث بضوضاء متوسطها صفري. المطلوب: العلاقة. الحل: الخطوة 1: الانحراف عن المسار الحتمي $\approx$ مارتنغيال. النتيجة: نستخدم أزوما لتحليل التقارب. الربط بالذكاء الاصطناعي: براهين تقارب محسّنات التدرّج.

مثال (19.8-12): مركزيّة الحدّ للمارتنغيالات المعطيات: فروق مارتنغيالية بتباين تراكمي. المطلوب: التقارب. الحل: الخطوة 1: CLT مارتنغيالي $\Rightarrow$ غاوسي مقارب. النتيجة: توزيع مقارب. الربط بالذكاء الاصطناعي: فواصل ثقة لتقديرات متسلسلة.

مثال (19.8-13): التوقّف الأمثل المعطيات: متى نبيع أصلاً؟ المطلوب: الإطار. الحل: الخطوة 1: نعظّم $\mathbb{E}[M_\tau]$ على أزمنة التوقّف $\Rightarrow$ سنيل (Snell envelope). النتيجة: استراتيجية توقّف مثلى. الربط بالذكاء الاصطناعي: قرارات الشراء/البيع الآلية.

مثال (19.8-14): الاختبار التتابعي المعطيات: نراقب البيانات ونتوقّف عند دليل كافٍ. المطلوب: الضبط. الحل: الخطوة 1: SPRT يستخدم نسبة احتمال مارتنغيالية مع حدود. النتيجة: كفاءة في عدد العيّنات. الربط بالذكاء الاصطناعي: testing A/B تتابعي.

مثال (19.8-15): دالّة القيمة في RL المعطيات: $V(s)$ وديناميكية MDP. المطلوب: العلاقة بالمارتنغيال. الحل: الخطوة 1: $V(s_t)+$ المكافآت المتراكمة = مارتنغيال تحت السياسة المثلى. النتيجة: (Bellman) $V - Q$ «خطأ TD» متوسطه صفري عند التقارب. الربط بالذكاء الاصطناعي: TD-learning وتقارب Q-learning.

أخطاء شائعة

- استخدام التوقّف الاختياري دون شروط المحدوديّة/التكامل الموحّد.
- الخلط بين مارتنغيال وعملية ماركوف (الأول عن المتوقّع المشروط).
- نسيان شرط التكيّف مع $\mathcal{F}_t$.
- الظن أن $\mathbb{E}[M_t]$ ثابت $\Rightarrow$ مارتنغيال (العكس غير صحيح).

ملخّص النظريات

النظرية	المفهوم	التطبيق في الذكاء الاصطناعي
19.2 الثبات/ACF	$\rho(h) = \gamma(h)/\gamma(0)$	تشخيص drfit والارتباط الزمني
19.3 AR	$X_t = c + \sum \phi_i X_{t-i} + \varepsilon_t$	التنبّؤ، النماذج التراجعية
19.4 MA/ARMA	$\Phi(L)X = \Theta(L)\varepsilon$	تنبّؤ رشيق، كشف شذوذ
19.5 RW/ARIMA	$\Phi(L)\nabla^d X = \Theta(L)\varepsilon$	التنبّؤ التشغيلي
19.6 بواسون	$N(t) \sim \text{Poisson}(\lambda t)$	الطوابير، الحمل، الأعطال
19.7 براونية/SDE	$dX = \mu dt + \sigma dW$	نماذج الانتشار، المالية
19.8 مارتنغيال	$\mathbb{E}[M_{t+1} \mid \mathcal{F}_t] = M_t$	تقارب SGD، الاختبار التتابعي

عشرون تمريناً (مع إجابات مختصرة)

١. عرّف الثبات الضعيف. (المتوسط ثابت والتغوّر دالة في التأخّر)

٢. احسب $\rho(2)$ لـ AR(1) بـ $\phi = 0.5$. (0.25)

٣. متى AR(1) غير ثابت؟ ($|\phi| \geq 1$)

٤. متوسط AR(1) بـ $c = 3, \phi = 0.5$. (6)

٥. تباين AR(1) بـ $\sigma^2 = 4, \phi = 0.5$. ($4/0.75 \approx 5.33$)

٦. اذكر ACF لـ MA(1). ($\rho(1) = \theta/(1+\theta^2)$، صفر بعده)

٧. شرط انعكاس MA(1). ($|\theta| < 1$)

٨. لماذا المشي العشوائي غير ثابت؟ (التباين $= t\sigma^2$)

٩. ما ARIMA(0,1,0)؟ (المشي العشوائي)

١٠. متى نتوقّف عن التفاضل؟ (عند اجتياز ADF)

١١. احسب $\mathbb{E}[N(5)]$ بـ $\lambda = 3$. (15)

١٢. توزيع فاصل الوصول بـ $\lambda = 2$. (Exp(2)، متوسط 0.5)

١٣. اذكر خاصّيتي وينر. (زيادات مستقلّة غاوسية، مسارات متّصلة)

١٤. حلّ GBM. ($S_t = S_0 e^{(\mu - \sigma^2/2)t + \sigma W_t}$)

١٥. أكمل لمّة إيتو لـ W^2. ($d(W^2) = 2W\,dW + dt$)

١٦. اشرح OU كـ AR(1) مستمرّ. ($\phi = 1 - \theta\Delta$)

١٧. عرّف المارتنغيال. ($\mathbb{E}[M_{t+1} \mid \mathcal{F}_t] = M_t$)

١٨. احتمال إفلاس المقامر برأس مال i من N. (i/N)

١٩. لماذا نسبة الاحتمال مارتنغيال تحت H_0؟ (توسّط تكاملي)

٢٠. اربط أزوما بالمارتنغيالات. (قيد تركيز لفروق مقيدة)

فهرس الرموز

الرمز	المعنى
$\gamma(h), \rho(h)$	التغوّر والارتباط الذاتي
ϕ_i, θ_j	معاملات AR و MA
L, ∇	مؤثّرا التأخّر والفرق
$N(t), \lambda$	عملية العدّ ومعدّلها
W_t	عملية وينر
$\mathcal{F}_t, M_t, \tau$	الترشيح، المارتنغيال، زمن التوقّف

مراجع

- Davis & Brockwell — *Time Series: Theory and Methods*.
- Hamilton — *Time Series Analysis*.
- Ross — *Stochastic Processes*.
- Øksendal — *Stochastic Differential Equations*.
- Shreve — *Stochastic Calculus for Finance*.
- Williams — *Probability with Martingales*.

خاتمة الجزء الثالث: بهذا الفصل تكتمل رحلة الاحتمالات والإحصاء (الفصول 13–19). ننتقل في الجزء الرابع إلى **التحسين** (الفصول 20–25)، حيث تلتقي هذه الاحتمالات مع حساب التفاضل (الجزء الثاني) لتشكّل نظرية تعلّم الآلة كما نعرفها.

القسم IV

التحسين

نبذة عن هذا الجزء

إذا كان التعلّم هو ضبط المعاملات لتقليل الخطأ، فالتحسين هو علم ذلك الضبط. نبدأ بـ**المسائل غير المقيّدة** وشروط الأمثلية: متى نقول إننا وصلنا؟ ثم ندخل عالم **القيود** مع شرط KKT والثنائيّة، حيث تتحوّل القيود إلى أسعارٍ ظلّيّة للموارد. يأتي بعدها **التحسين المحدّب** بموعوده الذهبية: الأدنى الوحيد عالميّ، وثنائيّة فنشل التي تمنح كل دالّة زواياها. ثم إلى الواقع العملي: **خوارزميات التدرّج العشوائي** من SGD إلى Adam وآليات سرعات التعلّم، فـ**التحسين الريماني** عندما تعيش المعاملات على متعدّد شعب لا على فضاء مستوٍ، ونختم بـ**التحسين الصندوق الأسود والموزَّع** حين لا يتوفّر تدرّج أصلاً أو تتوزّع الحوسبة على آلاتٍ متعدّدة. من يقرأ هذا الجزء يفهم لماذا «يتقارب» التدريب فعلاً — ولماذا أحياناً لا يتقارب. **فصول الجزء:** الأمثلية غير المقيّدة وشروط الأمثلية · القيود وKKT والثنائيّة · التحسين المحدّب والثنائيّة الفنشفلية · خوارزميات التدرّج SGD/Adam · التحسين الريماني · التحسين الصندوق الأسود والموزّع.

فصول هذا الجزء

- **الفصل 20.** التحسين غير المقيّد واختبارات الأمثلية
- **الفصل 21.** التحسين المقيّد: KKT والثنائية
- **الفصل 22.** التحسين المحدّب ونظرية الازدواج
- **الفصل 23.** خوارزميات التدرّج: SGD، الزخم، L-BFGS Adam،
- **الفصل 24.** التحسين على المتشعّبات (Riemannian Optimization)
- **الفصل 25.** التحسين التوزيعي والتحسين الأسود

التحسين غير المقيّد واختبارات الأمثلية

«كلّ تعلّمٍ هو تحسين: نبحث عن النقطة التي يقلّ عندها الخطأ.»

بهذا الفصل نفتتح **الجزء الرابع (التحسين).** كلّ ما بنيناه في التفاضل (الجزء الثاني) والاحتمالات (الجزء الثالث) يلتقي هنا: التدرّج من الفصل 9، الهِسّية من 3.9، المصفوفات الموجبة من 5.15، والتقدير بالاحتمال الأقصى من 2.18 — كلّها تصبّ في سؤال واحد: كيف نجد $x^\star$ التي ت minimized f؟
سبع نظريات:

- **2.20 شرط الرتبة الأولى** — التدرّج يصفُر عند الأمثلية (فيرما).
- **3.20 شروط الرتبة الثانية** — الهِسّية تفصل الأصغرى عن السرج.
- **4.20 التحدّب** — متى تصير النقطة الحرجة عالمية؟
- **5.20 السلاسة والتحدّب القوي** — رقم الحالة يحدّد الصعوبة.
- **6.20 البحث الخطّي** — كيف نختار طول الخطوة؟
- **7.20 هبوط التدرّج ومعدّلات التقارب** — كم نحتاج من التكرارات؟
- **8.20 نيوتن وشبه نيوتن** — استخدام الانحناء للقفز أبعد.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

نريد حلّ $\min_{x\in\mathbb{R}^n} f(x)$ بلا قيود.

الرمز	المعنى
f	الدالّة الهدف (objective / loss)
∇f	التدرّج
$\nabla^2 f$	الهِسّية (من 3.9)
$x^\star$	النقطة المثلى
L	ثابت السلاسة (Lipschitz) للتدرّج
μ	ثابت التحدّب القوي
κ	رقم الحالة L/μ

إذا كانت f قابلة للاشتقاق و $x^\star$ أصغريّة محلّية، فإنّ:

$$\nabla f(x^\star) = 0 \tag{1.20}$$

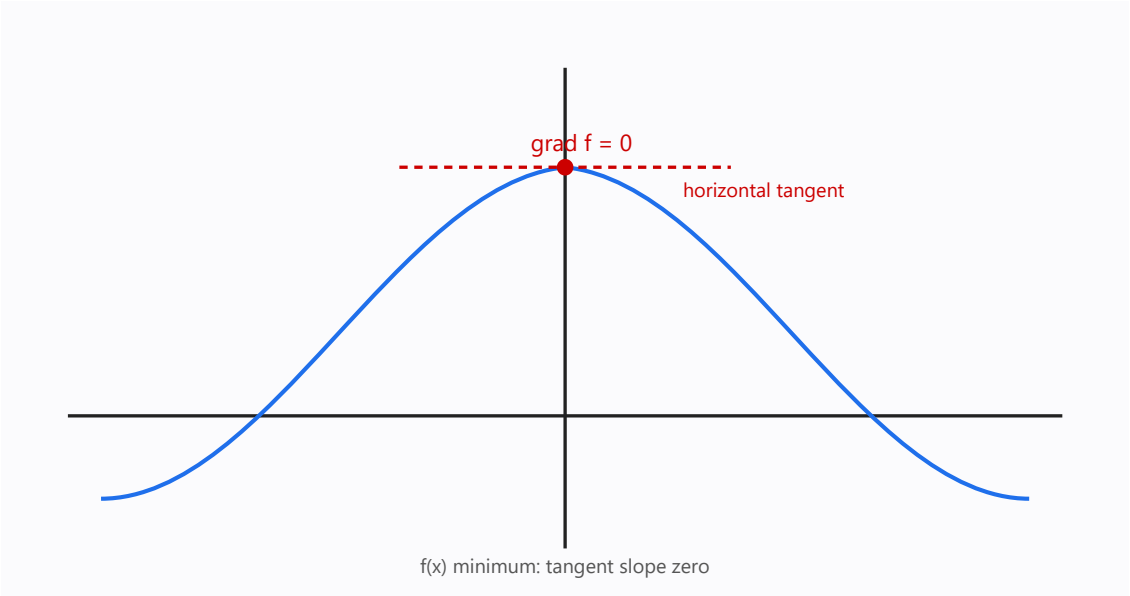
وأيّ نقطة تحقّق ذلك تُسمّى **نقطة حرجة** (stationary/critical).

جدول الرموز

الرمز	المعنى
$x^\star$	النقطة المثلى المحلّية
∇f	متّجه التدرّج
نقطة حرجة	$\nabla f = 0$

الرسم

<figure> الشكل<figcaption> 1.20: عند القمّة/القاع/السرج يكون المماس أفقيّاً؛ التدرّج يصفُر.</figcaption>



شكل ١.٢٠: *
شرط الرتبة الأولى: التدرج يصفر عند الأمثلية

</figure>

البرهان (مخطّط)

لأيّ اتجاه d، الدالّة $g(t) = f(x^\star + td)$ لها أصغريّة محلّية عند $t = 0$، فبقاعدة السلسلة $g'(0) = \nabla f(x^\star)^\top d = 0$ لكلّ d. باختيار $d = \nabla f(x^\star)$ نحصل على $\|\nabla f(x^\star)\|^2 = 0$، أي (1.20). ■

خمسة عشر مثالاً محلولاً

مثال (1-2.20): القطع المكافئ المعطيات: $f(x) = x^2$. المطلوب: النقطة الحرجة. الحل: الخطوة 1: $\nabla f = 2x$. الخطوة 2: $2x = 0 \Rightarrow x^\star = 0$. النتيجة: $x^\star = 0$ (أصغرى). الربط بالذكاء الاصطناعي: أبسط دالّة خسارة تربيعيّة.

مثال (2-2.20): التكعيب — سرج لا أصغرى المعطيات: $f(x) = x^3$ عند $x = 0$. المطلوب: هل هي أصغرى؟ الحل: الخطوة 1: $\nabla f = 3x^2 = 0$ عند 0. الخطوة 2: لكن f تصعد يساراً ويميناً $\Rightarrow$ نقطة انعطاف. النتيجة: نقطة حرجة ليست أصغرى. الربط بالذكاء الاصطناعي: تحذير: $\nabla f = 0$ لا يكفي.

مثال (3-2.20): الربع المعطيات: $f(x) = x^4$. المطلوب: النقطة الحرجة ونوعها. الحل: الخطوة 1: $\nabla f = 4x^3 = 0 \Rightarrow x = 0$. الخطوة 2: $f \geq 0 = f(0) \Rightarrow$ أصغرى. النتيجة: أصغرى (رغم $\nabla^2 f = 0$). الربط بالذكاء الاصطناعي: الرتبة الثانية قد تعجز (انظر 3.20).

مثال (20.2-4): ثنائي الأبعاد بسيط المعطيات: $f(x,y) = x^2 + y^2$. المطلوب: النقطة الحرجة. الحل: الخطوة 1: $\nabla f = (2x, 2y)$. الخطوة 2: $(0,0)$. النتيجة: الأصل. الربط بالذكاء الاصطناعي: خسارة تربيعيّة في فضاء معاملات.

مثال (20.2-5): المربّعات الصغرى المعطيات: $f(w) = \|Xw - y\|^2$. المطلوب: المعادلة الحرجة. الحل: الخطوة 1: $\nabla f = 2X^\top(Xw - y)$. الخطوة 2: $X^\top Xw = X^\top y \Rightarrow 0 =$ (المعادلات النظامية). النتيجة: $\hat{w} = (X^\top X)^{-1}X^\top y$. الربط بالذكاء الاصطناعي: الانحدار الخطّي حلّ مغلق (من الفصل 4).

مثال (20.2-6): اللوجستي — بلا حلّ مغلق المعطيات: خسارة الإنتروبيا المتقاطعة اللوجستية. المطلوب: المعادلة الحرجة. الحل: الخطوة 1: $\nabla f = \sum(\sigma_i - y_i)x_i = 0$. الخطوة 2: لا حلّ مغلق $\Rightarrow$ حلّ تكراري. النتيجة: نحتاج هبوط التدرّج/نيوتن. الربط بالذكاء الاصطناعي: لماذا نحتاج محسّنات تكرارية.

مثال (20.2-7): نقطة سرج ثنائية المعطيات: $f(x,y) = x^2 - y^2$. المطلوب: النقطة الحرجة ونوعها. الحل: الخطوة 1: $\nabla f = (2x, -2y) = 0 \Rightarrow (0,0)$. الخطوة 2: أصغرى في x، عظمى في $y \Rightarrow$ سرج. النتيجة: نقطة سرج. الربط بالذكاء الاصطناعي: السروج كثيرة في الشبكات العميقة.

مثال (20.2-8): غير قابلة للاشتقاق المعطيات: $f(x) = |x|$ عند 0. المطلوب: هل ينطبق فيرما؟ الحل: الخطوة 1: f غير قابلة للاشتقاق عند 0. الخطوة 2: الأصغرى عند 0 لكن بلا تدرّج. النتيجة: الشرط غير منطبق؛ نستخدم التدرّج الجزئي (subgradient). الربط بالذكاء الاصطناعي: تنظيم L1 غير قابل للاشتقاق.

مثال (20.2-9): غير مقيّد مقابل مقيّد المعطيات: نضيف قيداً $\|x\| \le 1$. المطلوب: الفرق. الحل: الخطوة 1: في غير المقيّد $\nabla f = 0$؛ في المقيّد قد لا يصفُر. النتيجة: الفصل 21 يعالج المقيّد (KKT). الربط بالذكاء الاصطناعي: قيود على الأوزان/الموارد.

مثال (20.2-10): تصنيف النقاط الحرجة المعطيات: جدول $(\nabla f, \nabla^2 f)$. المطلوب: القاعدة. الحل: الخطوة 1: $\nabla f = 0$ + 0 $\succ$ $\nabla^2 f \Rightarrow$ أصغرى. الخطوة 2: 0 $\prec$ $\nabla^2 f \Rightarrow$ عظمى؛ غير محدّد $\Rightarrow$ سرج. النتيجة: جدول التصنيف. الربط بالذكاء الاصطناعي: تشخيص نقاط التوقّف في التدريب.

مثال (20.2-11): ريدج المعطيات: $f(w) = \|Xw - y\|^2 + \lambda\|w\|^2$. المطلوب: المعادلة الحرجة. الحل: الخطوة 1: $\nabla f = 2(X^\top X + \lambda I)w - 2X^\top y$. الخطوة 2: $w = (X^\top X + \lambda I)^{-1}X^\top y$ =. 0 $\Rightarrow$ 0. النتيجة: ريدج (من 3.18). الربط بالذكاء الاصطناعي: التنظيم يجعل الحلّ فريداً ومستقرّاً.

مثال (20.2-12): MLE كلحظة حرجة المعطيات: نعظّم $\ell(\theta)$. المطلوب: العلاقة. الحل: الخطوة 1: تعظيم ℓ = تقليل $-\ell$؛ $\nabla\ell = 0$. النتيجة: التدريب = إيجاد نقطة حرجة. الربط بالذكاء الاصطناعي: وصل الفصل 18 بالتحسين.

مثال (20.2-13): الشبكة العصبية — سروج لا عظميات المعطيات: خسارة شبكة عميقة. المطلوب: طبيعة النقاط الحرجة. الحل: الخطوة 1: النقاط الحرجة غالباً سروج لا عظميات محلّية. النتيجة: الهروب من السرج أصعب من الهروب من العظمى. الربط بالذكاء الاصطناعي: لماذا SGD ينجح (الضوضاء تهرب).

مثال (20.2-14): فحص عددي للتدرّج المعطيات: نريد التأكّد من $\nabla f \approx 0$. المطلوب: المعيار. الحل: الخطوة 1: نستخدم $\|\nabla f\| \le \epsilon$ (مثلاً 10^{-6}). النتيجة: معيار توقّف عملي. الربط بالذكاء الاصطناعي: stopping early criterion.

مثال (20.2-15): تسوية الخسارة المعطيات: $f(w) = \frac{1}{n}\sum \ell_i(w) + \lambda R(w)$. المطلوب: البنية العامّة. الحل: الخطوة 1: $\nabla f = \frac{1}{n}\sum \nabla\ell_i + \lambda\nabla R$. النتيجة: الصيغة التي ندرّب عليها كلّ نموذج. الربط بالذكاء الاصطناعي: الهدف الموحّد لتعلّم الآلة.

أخطاء شائعة

- اعتبار $\nabla f = 0$ كافياً للأصغرى (ليس كذلك: قد يكون سرجاً).
- تطبيق الشرط على دوالّ غير قابلة للاشتقاق (مثل L1).

- الخلط بين النقطة الحرجة والأصغرى العالمية.
- نسيان أن شرط فيرما ضروري لا كافٍ.

ضروري: إذا $x^\star$ أصغرى محلّية و f مرّتين قابلة للاشتقاق، فـ $\nabla f(x^\star) = 0$ و $\nabla^2 f(x^\star) \succcurlyeq 0$. **كافٍ:** إذا $\nabla f(x^\star) = 0$ و $\nabla^2 f(x^\star) \succ 0$، فـ $x^\star$ أصغرى محلّية صارمة:

$$\nabla f(x^\star) = 0, \quad \nabla^2 f(x^\star) \succ 0 \implies x^\star \text{ أصغرى محلّية صارمة} \tag{2.20}$$

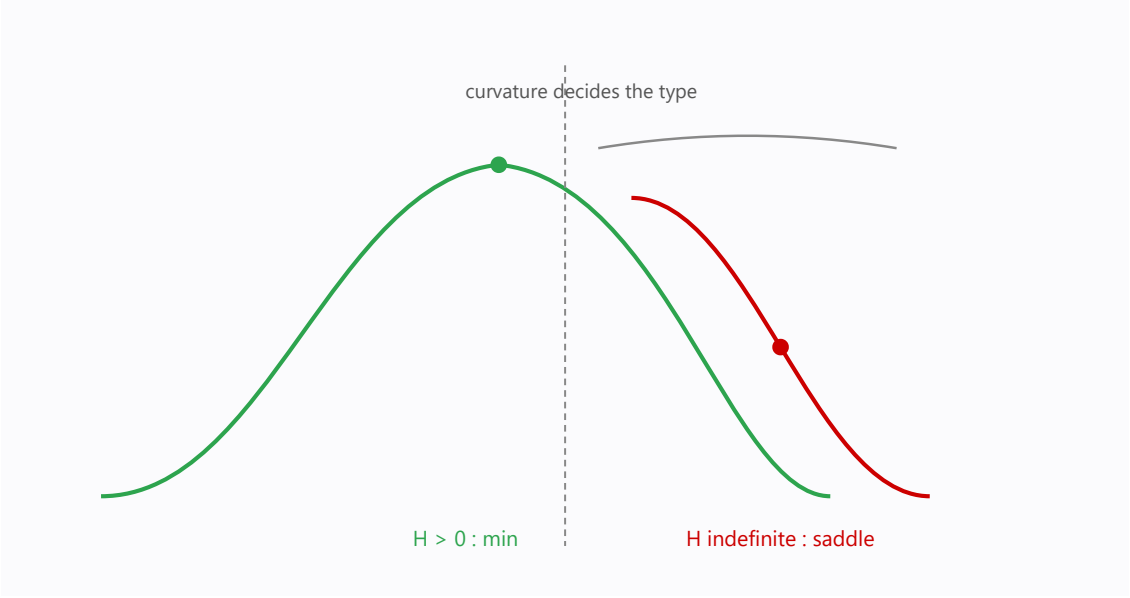
وإذا كانت الهِسّية غير محدّدة (لها قيمة ذاتية سالبة وموجبة) فالنقطة سرج.

جدول الرموز

الرمز	المعنى
$\nabla^2 f$	مصفوفة الهِسّية
$\succcurlyeq 0$	موجبة نصف التحديد (من 5.15)
$\succ 0$	موجبة التحديد
$\lambda_{\min}, \lambda_{\max}$	أصغر وأكبر قيمة ذاتية

الرسم

<figure> الشكل<figcaption> 2.20: الهِسّية موجبة التحديد ⇒ قاع، سالبة ⇒ قمّة، غير محدّدة ⇒



شكل ٢٠.٢٠: *
شروط الرتبة الثانية: الهسية تحدد النوع

سرج.</figcaption> </figure>

البرهان (مخطّط)

بتوسّع تايلور من الفصل 11: $f(x^\star + d) = f(x^\star) + \nabla f^\top d + \tfrac{1}{2} d^\top \nabla^2 f(x^\star) d + o(\|d\|^2)$. عند النقطة الحرجة الحدّ الأول يختفي؛ إن كانت الهِسّية موجبة التحديد فـ $d^\top H d \geq \lambda_{\min} \|d\|^2 > 0$ فيزداد f في كلّ اتجاه ⇒ أصغرى صارمة. ■

خمسة عشر مثالاً محلولاً

مثال (20.3-1): هِسّية موجبة $\Rightarrow$ أصغرى المعطيات: $f = x^2 + y^2$، $H = 2I$. المطلوب: النوع. الحل: الخطوة 1: القيم الذاتية $2, 2 > 0 \Rightarrow 0 \prec$. النتيجة: أصغرى صارمة. الربط بالذكاء الاصطناعي: خسارة محدّبة جيداً.

مثال (20.3-2): هِسّية غير محدّدة $\Rightarrow$ سرج المعطيات: $f = x^2 - y^2$، $H = \mathrm{diag}(2, -2)$. المطلوب: النوع. الحل: الخطوة 1: قيمتان ذاتيتان بإشارتين مختلفتين. النتيجة: سرج عند الأصل. الربط بالذكاء الاصطناعي: سروج الشبكات العميقة.

مثال (20.3-3): نصف التحديد $\Rightarrow$ غير حاسم المعطيات: $f = x^4$ عند 0، $H = 0$. المطلوب: هل نحسم؟ الحل: الخطوة 1: $H = 0 \succcurlyeq 0$ (نصف) لكن الرتبة الثانية لا تحسم. الخطوة 2: نفحص الرتبة الأعلى $\Rightarrow$ أصغرى. النتيجة: الحالة مبهمة. الربط بالذكاء الاصطناعي: نقاط مسطّحة/منطقة تكيّف سيّئة.

مثال (20.3-4): اختبار القيم الذاتية المعطيات: $H = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$. المطلوب: النوع. الحل: الخطوة 1: القيم الذاتية $3, 1 > 0$. النتيجة: $0 \prec \Rightarrow$ أصغرى. الربط بالذكاء الاصطناعي: فحص انحناء الخسارة.

مثال (20.3-5): شكل تربيعي المعطيات: $f = \frac{1}{2} x^\top A x - b^\top x$. المطلوب: شرط الأصغرى. الحل: الخطوة 1: $\nabla f = Ax - b$، $H = A$. الخطوة 2: $A \succ 0 \Rightarrow$ أصغرى فريدة عند $x = A^{-1} b$. النتيجة: الشرط الكامل. الربط بالذكاء الاصطناعي: خسارة تربيعيّة عامّة.

مثال (20.3-6): هِسّية المربّعات الصغرى المعطيات: $f(w) = \|Xw - y\|^2$. المطلوب: H. الحل: الخطوة 1: $H = 2X^\top X \succcurlyeq 0$. الخطوة 2: $0 \succ X$ ffi عمود كامل الرتبة. النتيجة: محدّب (وصرام مع رتبة كاملة). الربط بالذكاء الاصطناعي: لماذا الانحدار سهل التحسين.

مثال (20.3-7): هِسّية اللوجستي المعطيات: خسارة لوجستية. المطلوب: H ونوعها. الحل: الخطوة 1: $H = X^\top D X$ حيث $D = \mathrm{diag}(\sigma_i(1 - \sigma_i)) \succcurlyeq 0$. النتيجة: $H \succcurlyeq 0 \Rightarrow$ محدّب. الربط بالذكاء الاصطناعي: اللوجستي محدّب $\Rightarrow$ حلّ عالمي.

مثال (20.3-8): هِسّية الشبكة العصبية المعطيات: خسارة شبكة عميقة. المطلوب: طبيعة H. الحل: الخطوة 1: عادةً غير محدّدة (سروج كثيرة). النتيجة: تحسين غير محدّب. الربط بالذكاء الاصطناعي: صعوبة تدريب الشبكات نظريّاً.

مثال (20.3-9): محلّي مقابل عالمي المعطيات: دالّة غير محدّبة بقمم متعدّدة. المطلوب: الفرق. الحل: الخطوة 1: الرتبة الثانية تحسم **محلّياً** فقط. النتيجة: العالمية تحتاج تحدّباً (4.20). الربط بالذكاء الاصطناعي: نبدأ من تهيئات متعدّدة.

مثال (20.3-10): اتجاه مسطّح المعطيات: $H = \mathrm{diag}(2, 0)$. المطلوب: النوع. الحل: الخطوة 1: نصف محدّد؛ الاتجاه الثاني مسطّح. النتيجة: غير حاسم؛ قد لا يكون أصغرى صارمة. الربط بالذكاء الاصطناعي: اتجاهات «منطقة تكيّف» مسطّحة.

مثال (20.3-11): جوار كافٍ المعطيات: $\nabla^2 f(x^\star) \succ 0$. المطلوب: مدى النتيجة. الحل: الخطوة 1: يوجد جوار تكون فيه $f > f(x^\star)$. النتيجة: أصغرى محلّية صارمة. الربط بالذكاء الاصطناعي: ضمان موضعي لا عالمي.

مثال (20.3-12): انحناء سالب $\Rightarrow$ عظمى المعطيات: $f = -x^2$، $H = -2$. المطلوب: النوع. الحل: الخطوة 1: $H \prec 0 \Rightarrow$ عظمى. النتيجة: نعظّم لا نقلّل. الربط بالذكاء الاصطناعي: تعظيم الاحتمال = تقليل السالب (2.18).

مثال (20.3-13): رقم حالة الهِسّية المعطيات: H بقيم 100 و 1. المطلوب: الأثر. الحل: الخطوة 1: $\kappa = 100 \Rightarrow$ وادٍ ضيّق. النتيجة: الهبوط متعرّج (zigzag). الربط بالذكاء الاصطناعي: لماذا نحتاج تسريعاً/تكييفاً (5.20).

مثال (20.3-14): تعديل نيوتن للسروج المعطيات: H غير محدّدة في خطوة نيوتن. المطلوب: المعالجة. الحل: الخطوة 1: نضيف λI حتى تصير $0 \prec$ (trust-region/Levenberg). النتيجة: اتجاه هبوط مضمون. الربط بالذكاء الاصطناعي: Levenberg–Marquardt (من 7.11).

مثال (15-3.20): الجدول الختامي المعطيات: أربع حالات. المطلوب: التلخيص. الحل: الخطوة 1: $0 \succ$ أصغرى؛ $0 \prec$ عظمى؛ غير محدّد سرج؛ نصف محدّد مبهم. النتيجة: جدول التصنيف الكامل. الربط بالذكاء الاصطناعي: مرجع سريع لتشخيص التدريب.

أخطاء شائعة

- اعتبار $\nabla^2 f \succcurlyeq 0$ كافياً (هو ضروري فقط؛ x^4 مثال مضادّ).
- نسيان فحص $\nabla f = 0$ أولاً.
- الخلط بين موجبة التحديد ونصف التحديد.
- قراءة رقم الحالة دون أثره على سرعة الهبوط.

f محدّبة إذا كان لأيّ x, y و $t \in [0,1]$: $f(tx + (1-t)y) \le t f(x) + (1-t) f(y)$. وبالرتبة الأولى:

$$f(y) \;\ge\; f(x) + \nabla f(x)^{\top}(y - x) \qquad \text{و} \qquad \nabla^2 f(x) \succcurlyeq 0 \;\forall x \tag{3.20}$$

وإذا كانت f محدّبة و $\nabla f(x^\star) = 0$ فـ $x^\star$ **أصغرى عالمية.**

جدول الرموز

الرمز	المعنى
محدّبة	القطعة المستقيمة فوق الرسم
$\succcurlyeq 0$	الهِسّية موجبة نصف التحديد everywhere
عالمية	كلّ نقطة حرجة عالمية

الرسم

<figure> الشكل<figcaption> 3.20: في الدالّة المحدّبة كلّ نقطة حرجة هي أصغرى عالمية؛ لا سروج مضلّلة.</figcaption> </figure>

البرهان (مخطّط)

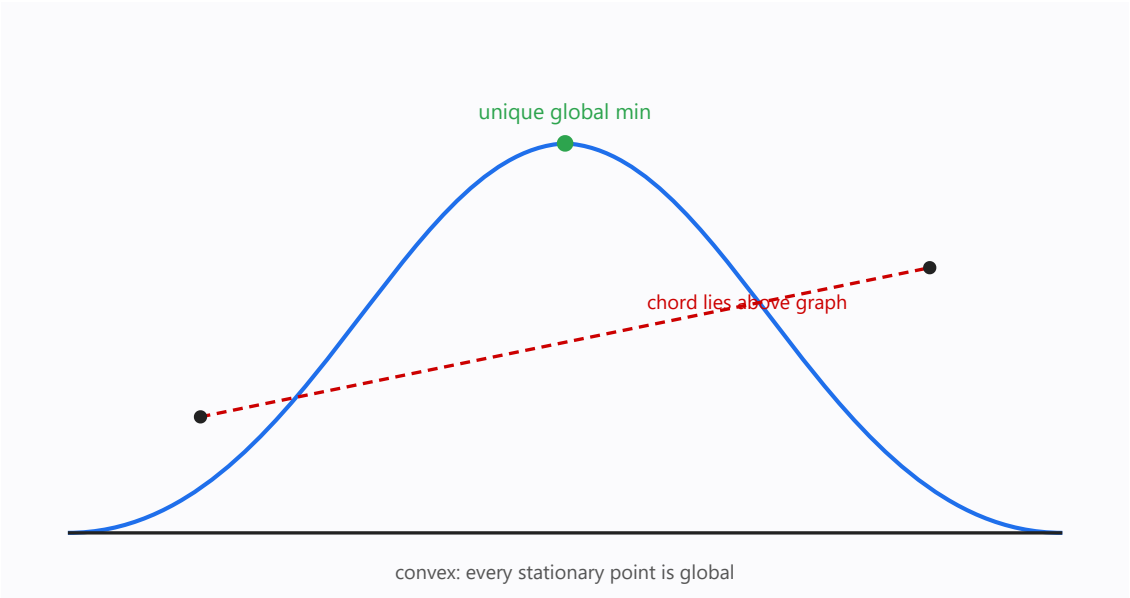
من (3.20) بوضع $y = x^\star$: $f(x^\star) \ge f(x) + \nabla f(x)^{\top}(x^\star - x)$. وإن كان $\nabla f(x) = 0$ أيضاً فـ $f(x) \ge f(x^\star)$، أي $x^\star$ عالمية. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.20): تعريف جنسن المعطيات: f محدّبة، $t = 0.5$. المطلوب: المتراجحة. الحل: الخطوة 1: $f(\frac{x+y}{2}) \le \frac{f(x)+f(y)}{2}$. النتيجة: المتوسط فوق الصورة. الربط بالذكاء الاصطناعي: جنسن من 4.15 تُستخدم هنا.

مثال (2-4.20): متراجحة الرتبة الأولى المعطيات: f محدّبة قابلة للاشتقاق. المطلوب: الصيغة. الحل: الخطوة 1: $f(y) \ge f(x) + \nabla f(x)^{\top}(y-x)$ (مماسّ تحت الرسم). النتيجة: أساس إثبات التقارب. الربط بالذكاء الاصطناعي: تحليل هبوط التدرّج.

مثال (3-4.20): الرتبة الثانية والتحدّب المعطيات: f مرّتين قابلة للاشتقاق. المطلوب: المعيار. الحل: الخطوة 1: f محدّبة ffi $\nabla^2 f(x) \succcurlyeq 0$ لكلّ x. النتيجة: اختبار عملي. الربط بالذكاء الاصطناعي: التحقّق من محدّدية النموذج.



شكل ٣.٢٠: *
التحدب: المستقيم فوق المنحنى والأمثلية العالمية

مثال (4-4.20): x^2 محدّبة المعطيات: $f = x^2$. المطلوب: البرهان. الحل: الخطوة 1: $\nabla^2 f = 2 \geq 0$. النتيجة: محدّبة. الربط بالذكاء الاصطناعي: خسارة MSE.

مثال (5-4.20): e^x محدّبة المعطيات: $f = e^x$. المطلوب: البرهان. الحل: الخطوة 1: $\nabla^2 f = e^x > 0$. النتيجة: محدّبة صارمة. الربط بالذكاء الاصطناعي: خسارة أسّية/بواسون.

مثال (6-4.20): $-\log x$ محدّبة المعطيات: $f = -\log x$ على $x > 0$. المطلوب: البرهان. الحل: الخطوة 1: $\nabla^2 f = 1/x^2 > 0$. النتيجة: محدّبة. الربط بالذكاء الاصطناعي: خسارة السجلّ/الإنتروبيا المتقاطعة.

مثال (7-4.20): $|x|$ محدّبة غير سلسة المعطيات: $f = |x|$. المطلوب: التحدّب. الحل: الخطوة 1: محدّبة (من المتراجحة المثلثية) لكن غير قابلة للاشتقاق عند 0. النتيجة: محدّبة غير سلسة. الربط بالذكاء الاصطناعي: تنظيم L1 (لاسو).

مثال (8-4.20): مجموع المحدّبات المعطيات: f_i محدّبة. المطلوب: $\sum \alpha_i f_i$ بـ $\alpha_i \geq 0$. الحل: الخطوة 1: محدّبة (مجموع مرجّح). النتيجة: خسارة + تنظيم محدّب. الربط بالذكاء الاصطناعي: تركيب الأهداف.

مثال (9-4.20): الأعظمي للمحدّبات المعطيات: $f = \max(f_1, f_2)$ محدّبتان. المطلوب: النوع. الحل: الخطوة 1: محدّبة epigraph) تقاطع). النتيجة: خسارة hinge/SVM محدّبة. الربط بالذكاء الاصطناعي: SVM (الفصل 30).

مثال (10-4.20): قواعد التركيب المعطيات: $f(g(x))$. المطلوب: متى محدّبة؟ الحل: الخطوة 1: f محدّبة غير متناقصة + g محدّبة $\Rightarrow$ محدّبة. النتيجة: قواعد البناء. الربط بالذكاء الاصطناعي: تصميم خسائر محدّبة.

مثال (11-4.20): محدّب + حرج $\Rightarrow$ عالمي المعطيات: f محدّبة، $\nabla f(x^\star) = 0$. المطلوب: النتيجة. الحل: الخطوة 1: من (3.20) مع y عشوائي: $f(y) \geq f(x^\star)$. النتيجة: لا سروج؛ التحسين «سهل». الربط بالذكاء الاصطناعي: لماذا اللوجستي/الخطّي مضمونة.

مثال (12-4.20): المربّعات الصغرى محدّبة المعطيات: $H = 2X^\top X \succcurlyeq 0$. المطلوب: الحكم. الحل: الخطوة 1: محدّبة (صرام مع رتبة كاملة). النتيجة: حلّ عالمي فريد. الربط بالذكاء الاصطناعي: الانحدار موثوق.

مثال (13-4.20): اللوجستي محدّبة المعطيات: $H = X^\top D X \succcurlyeq 0$. المطلوب: الحكم. الحل: الخطوة 1: محدّبة.

النتيجة: لا أصغريات محلّية سيّئة. الربط بالذكاء الاصطناعي: ضمان التدريب.

مثال (20.4-14): الشبكة غير محدّبة المعطيات: شبكة بطبقة مخفيّة. المطلوب: التحدّب؟ الحل: الخطوة 1: غير محدّبة (تباديل الأوزان المتماثلة، غير خطّية). النتيجة: تحسين غير محدّب عملياً ناجح. الربط بالذكاء الاصطناعي: يبرّر دراسة السروج لا العظميات.

مثال (20.4-15): جنسن والتوقّع المعطيات: f محدّبة. المطلوب: المتراجحة. الحل: الخطوة 1: $f(\mathbb{E}[X]) \le \mathbb{E}[f(X)]$ (من 4.15). النتيجة: وصل التحسين بالاحتمال. الربط بالذكاء الاصطناعي: حدود التعميم (الفصل 30).

أخطاء شائعة

- الظن أن كلّ خسارة في تعلّم الآلة محدّبة (الشبكات ليست كذلك).
- نسيان أن التحدّب شرط على **كلّ** الفضاء لا عند نقطة.
- الخلط بين المحدّب والسلس ($|x|$ محدّب غير سلس).
- استخدام «أصغرى محلّية» كمبرّر عند وجود التحدّب.

f **سلسة بـ** L إذا $\|\nabla f(x)-\nabla f(y)\| \le L\|x-y\|$، **وقوية التحدّب بـ** μ إذا $f(y) \ge f(x)+\nabla f^\top(y-x)+\frac{\mu}{2}\|y-x\|^2$. بالهِسّية:

$$\mu I \preccurlyeq \nabla^2 f(x) \preccurlyeq L I, \qquad \kappa = \frac{L}{\mu} \tag{4.20}$$

جدول الرموز

الرمز	المعنى
L	ثابت ليبشتز للتدرّج (السلاسة)
μ	ثابت التحدّب القوي
κ	رقم الحالة L/μ

الرسم

<figure> الشكل<figcaption> 4.20: انحناء بين μ و L؛ كلّما كبر $L/\mu = \kappa$ ضاق الوادي وتعرّج الهبوط.</figcaption></figure>

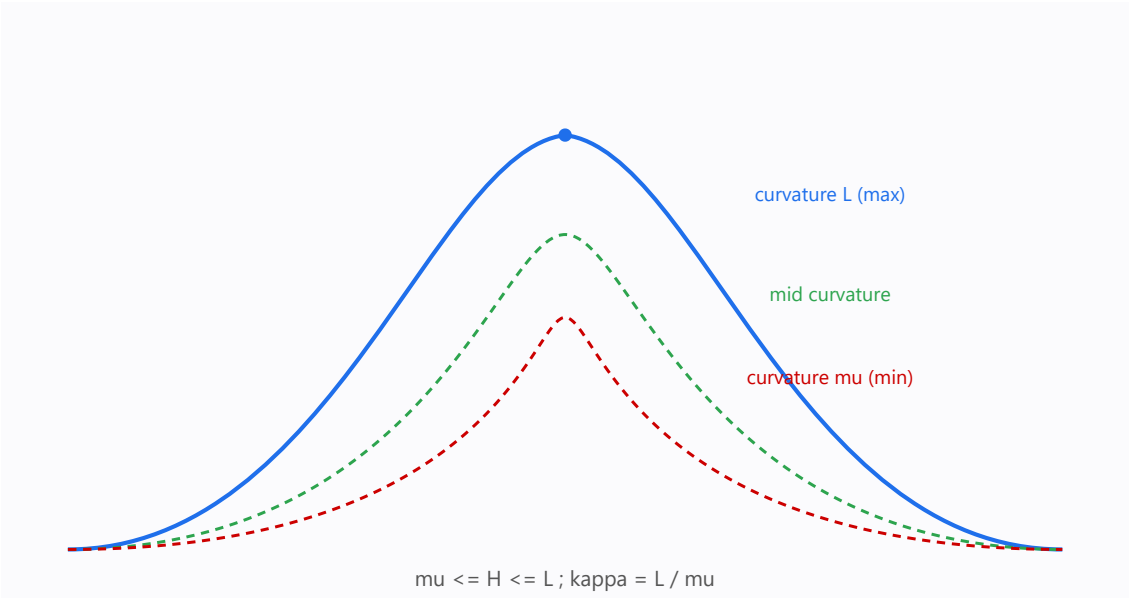
البرهان (مخطّط)

بالرتبة الثانية: L-سلاسة $\Leftrightarrow \lambda_{\max}(\nabla^2 f) \le L$ (من تمديد قيمة متوسّطة للتدرّج، الفصل 6.8)؛ و μ-تحدّب قوي $\Leftrightarrow \lambda_{\min}(\nabla^2 f) \ge \mu$. ومنه (4.20) بترتيب القيم الذاتية (الفصل 4). ■

خمسة عشر مثالاً محلولاً

مثال (5.20-1): تعريف السلاسة المعطيات: $\|\nabla f(x)-\nabla f(y)\| \le L\|x-y\|$. المطلوب: التفسير. الحل: الخطوة 1: التدرّج لا يتغيّر أسرع من L. النتيجة: حدّ على الانحناء الأقصى. الربط بالذكاء الاصطناعي: يحدّد أكبر خطوة آمنة.

مثال (5.20-2): متراجحة الهبوط المعطيات: f سلسة بـ L. المطلوب: نتيجة خطوة واحدة. الحل: الخطوة 1: $f(x-\eta\nabla f) \le f(x)-\eta(1-\frac{\eta L}{2})\|\nabla f\|^2$ (انظر 6.20). النتيجة: ضمان النقصان بـ $\eta < 2/L$. الربط بالذكاء الاصطناعي: تبرير اختيار معدّل التعلّم.



شكل ٢٠.٤: *
السلاسة والتحدب القوي ورقم الحالة

مثال (3-5.20): تعريف التحدّب القوي المعطيات: المتراجحة بـ $\frac{\mu}{2}\|y - x\|^2$. المطلوب: المعنى. الحل: الخطوة 1: انحناء أدنى إيجابي؛ لا مناطق مسطّحة. النتيجة: أصغرى فريدة. الربط بالذكاء الاصطناعي: التنظيم يجعل الخسارة قوية التحدّب.

مثال (4-5.20): رقم الحالة المعطيات: $\mu = 1$، $L = 100$. المطلوب: κ. الحل: الخطوة 1: $\kappa = 100$. النتيجة: تحسين «صعب» نسبيّاً. الربط بالذكاء الاصطناعي: عدد التكرارات يتناسب مع κ.

مثال (5-5.20): التربيعي المعطيات: $f = \frac{1}{2}x^\top Ax$. المطلوب: L, μ. الحل: الخطوة 1: $L = \lambda_{\max}(A)$، $\mu = \lambda_{\min}(A)$. الخطوة 2: $\kappa = \kappa(A)$ (من الفصل 4). النتيجة: رقم حالة المصفوفة نفسه. الربط بالذكاء الاصطناعي: لماذا تكييف الميزات مهمّ.

مثال (6-5.20): أثر سوء التكييف على الهبوط المعطيات: وادٍ ضيّق $\kappa = 1000$. المطلوب: السلوك. الحل: الخطوة 1: الهبوط يتعرّج ذهاباً وإياباً. النتيجة: تقارب بطيء جدّاً. الربط بالذكاء الاصطناعي: تطبيع الميزات/التكييف المسبق.

مثال (7-5.20): ريدج يضيف تحدّباً قويّاً المعطيات: $f(w) + \frac{\lambda}{2}\|w\|^2$. المطلوب: μ الجديد. الحل: الخطوة 1: الهِسّية $H + \lambda I$، $\mu \geq \lambda \Rightarrow$. النتيجة: تحسين أسرع وأكثر استقراراً. الربط بالذكاء الاصطناعي: التنظيم يحسّن التكييف.

مثال (8-5.20): التكييف المسبق المعطيات: نغيّر المتغيّرات $z = P^{-1}x$. المطلوب: الهدف. الحل: الخطوة 1: نجعل رقم الحالة أقرب إلى 1. النتيجة: تسريع هائل. الربط بالذكاء الاصطناعي: Adam/Adagrad تكييف قطري.

مثال (9-5.20): L للّوجستي المعطيات: خسارة لوجستية بمدخلات X. المطلوب: تقدير L. الحل: الخطوة 1: $H = X^\top DX$، $D \preccurlyeq \frac{1}{4}I \Rightarrow L \leq \frac{1}{4}\lambda_{\max}(X^\top X)$. النتيجة: حدّ على الخطوة. الربط بالذكاء الاصطناعي: ضبط معدّل التعلّم نظريّاً.

مثال (10-5.20): خسارة منظّمة قوية التحدّب المعطيات: خسارة محدّبة + تنظيم L2. المطلوب: الحكم. الحل: الخطوة 1: صارت قوية التحدّب بـ $\mu = \lambda$. النتيجة: تقارب خطّي (7.20). الربط بالذكاء الاصطناعي: تقارب أسرع مع التنظيم.

مثال (11-5.20): شرط بولياك–لوجاسِفيتش (PL) المعطيات: $\frac{1}{2}\|\nabla f\|^2 \geq \mu(f - f^\star)$. المطلوب: الأهمّية.

الحل: الخطوة 1: أضعف من التحدّب القوي لكن يكفي لتقارب خطّي. النتيجة: يفسّر نجاح الشبكات غير المحدّبة. الربط بالذكاء الاصطناعي: نظرية حديثة للتعلّم العميق.

مثال (5.20-12): هِسّية الشبكات المعطيات: قيم ذاتية للهِسّية. المطلوب: الملاحظة. الحل: الخطوة 1: قليل من القيم الكبيرة وكثير قرب الصفر $\Rightarrow \kappa$ كبير. النتيجة: مشهد خسارة «وعر». الربط بالذكاء الاصطناعي: تسوية الخسارة/التطبيع بالدفعات.

مثال (5.20-13): اختيار الخطوة $\eta \le 1/L$ المعطيات: $L = 10$. المطلوب: خطوة آمنة. الحل: الخطوة 1: $\eta \le 0.1$. النتيجة: هبوط مضمون. الربط بالذكاء الاصطناعي: معدّل التعلّم الأقصى النظري.

مثال (5.20-14): تكرارات إلى ϵ المعطيات: نريد $f - f^\star \le \epsilon$ بـ $\kappa = 100$. المطلوب: عدد التكرارات. الحل: الخطوة 1: $O(\kappa \log(1/\epsilon))$. النتيجة: مئات التكرارات. الربط بالذكاء الاصطناعي: ميزانية التدريب.

مثال (5.20-15): سلاسة softmax المعطيات: خسارة إنتروبيا متقاطعة مع softmax. المطلوب: السلاسة. الحل: الخطوة 1: الهِسّية محدودة $\Rightarrow L$ منتهٍ. النتيجة: تحليل التقارب ممكن. الربط بالذكاء الاصطناعي: تدريب المصنّفات الكبيرة.

أخطاء شائعة

- الخلط بين L (انحناء أقصى) و μ (انحناء أدنى).
- نسيان أن $\mu = 0$ في غير قوي التحدّب $\Rightarrow$ تقارب أبطأ.
- الظن أن κ صغير دائماً بعد التطبيع.
- استخدام $\eta > 2/L$ فيتذبذب الهبوط أو يتباعد.

في اتجاه هبوط d (أي $\nabla f^\top d < 0$) نختار $\eta > 0$ يحقّق **شرط أرميخو** (نقصان كافٍ) **وشرط وولف**:

$$f(x + \eta d) \le f(x) + c_1 \eta \nabla f(x)^\top d, \qquad \nabla f(x + \eta d)^\top d \ge c_2 \nabla f(x)^\top d \tag{5.20}$$

بعادة $c_1 = 10^{-4}$ و $c_2 = 0.9$ (وولف القوي).

جدول الرموز

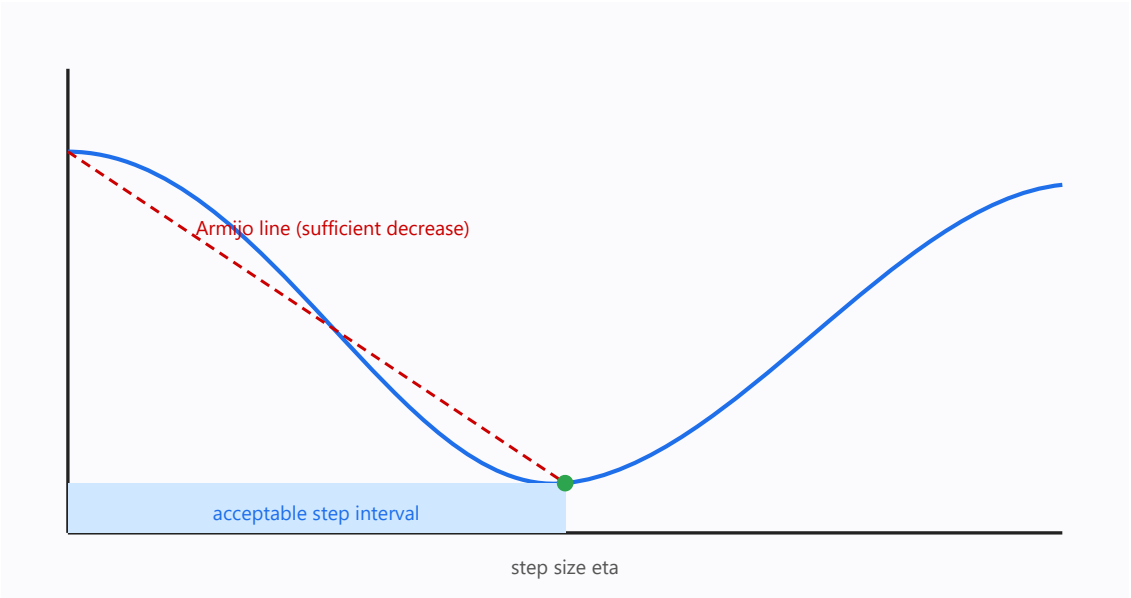
الرمز	المعنى
d	اتجاه الهبوط
η	طول الخطوة
c_1	ثابت النقصان الكافي
c_2	ثابت الانحناء (وولف)

الرسم

<figure> الشكل<figcaption> 5.20: نقبل η إذا نقصت القيمة كفاية (أرميخو) ولم تكن الخطوة قصيرة جدّاً (وولف).</figcaption> </figure>

البرهان (مخطّط)

الدالّة $\phi(\eta) = f(x + \eta d)$ متناقصة عند 0 (لأن d هبوط). شرط أرميخو يضمن $\phi(\eta)$ تحت الخطّ المائل؛ وولف يستبعد الخطوات القصيرة جدّاً التي لا تحرز تقدّماً. بخوارزمية التراجع (backtracking) نضرب $\eta \leftarrow \beta\eta$ حتى يتحقّق أرميخو. ■



شكل ٢٠.٥: *
البحث الخطي: شروط أرميخو وووولف

خمسة عشر مثالاً محلولاً

مثال (20.6-1): اتجاه الهبوط المعطيات: $d = -\nabla f$. المطلوب: التحقّق. الحل: الخطوة 1: $\nabla f^\top d = -\|\nabla f\|^2 < 0$. النتيجة: d اتجاه هبوط. الربط بالذكاء الاصطناعي: أساس هبوط التدرّج.

مثال (20.6-2): شرط أرميخو المعطيات: $c_1 = 10^{-4}$، نختبر η. المطلوب: القبول. الحل: الخطوة 1: نقارن $f(x+\eta d)$ بالخطّ المتوقّع. النتيجة: إن نقصت كفاية ⇒ نقبل. الربط بالذكاء الاصطناعي: تنفيذ محسّنات قويّة.

مثال (20.6-3): شرط وولف المعطيات: $c_2 = 0.9$. المطلوب: المعنى. الحل: الخطوة 1: الانحدار عند النقطة الجديدة أصغر مقداراً ⇒ خطوة ليست قصيرة جدّاً. النتيجة: يمنع التقدّم الضئيل. الربط بالذكاء الاصطناعي: استقرار L-BFGS.

مثال (20.6-4): وولف القوي المعطيات: نضيف $|\nabla f(x+\eta d)^\top d| \le c_2 |\nabla f^\top d|$. المطلوب: الفائدة. الحل: الخطوة 1: يستبعد الخطوات الطويلة جدّاً أيضاً. النتيجة: نطاق مقبول محصور. الربط بالذكاء الاصطناعي: ضبط أدقّ.

مثال (20.6-5): خوارزمية التراجع المعطيات: $\eta_0 = 1$، $\beta = 0.5$. المطلوب: الخطوات. الحل: الخطوة 1: نضاعف التراجع حتى يتحقّق أرميخو. النتيجة: η مقبول. الربط بالذكاء الاصطناعي: search line backtracking عملياً.

مثال (20.6-6): بحث خطّي دقيق للتربيعي المعطيات: $f = \frac{1}{2}x^\top A x$، $d = -\nabla f$. المطلوب: $\eta^\star$. الحل: الخطوة 1: $\eta^\star = \frac{\|\nabla f\|^2}{\nabla f^\top A \nabla f}$ (بالمشتقّة صفراً). النتيجة: خطوة مثالية مغلقة. الربط بالذكاء الاصطناعي: هبوط التدرّج الم conjugé (الفصل 21).

مثال (20.6-7): ضمان $\eta = 1/L$ المعطيات: f سلسة بـ L. المطلوب: هل $\eta = 1/L$ ينقص؟ الحل: الخطوة 1: من متراجحة الهبوط: $\eta(1 - \frac{\eta L}{2}) > 0$ ⇒ نعم. النتيجة: خطوة آمنة مضمونة. الربط بالذكاء الاصطناعي: بديل بسيط للبحث الخطّي.

مثال (20.6-8): خطوة كبيرة جدّاً المعطيات: $\eta = 5/L$. المطلوب: السلوك. الحل: الخطوة 1: قد تصعد القيمة أو يتباعد المسار. النتيجة: تذبذب/تباعد. الربط بالذكاء الاصطناعي: أعراض معدّل تعلّم كبير.

مثال (20.6-9): خطوة صغيرة جدّاً المعطيات: $\eta = 0.001/L$. المطلوب: السلوك. الحل: الخطوة 1: تقدّم ضئيل؛ تقارب بطيء جدّاً. النتيجة: إهدار حسابي. الربط بالذكاء الاصطناعي: معدّل تعلّم صغير جدّاً.

مثال (20.6-10): القيم النموذجية المعطيات: $c_1 = 10^{-4}$، $c_2 = 0.9$. المطلوب: التبرير. الحل: الخطوة 1: c_1 صغير ⇒ نقبل معظم الخطوات؛ c_2 قريب من 1 ⇒ خطوة جادّة. النتيجة: إعداد صناعي قياسي. الربط بالذكاء الاصطناعي: إعدادات مكتبات التحسين.

مثال (20.6-11): بحث خطّي مقابل خطوة ثابتة المعطيات: نقارن الطريقتين. المطلوب: المقايضة. الحل: الخطوة 1: البحث الخطّي يتكيّف لكنه يكلّف تقييمات إضافية. النتيجة: مفيد عندما L مجهول. الربط بالذكاء الاصطناعي: متى نستخدمه.

مثال (20.6-12): منطقة الثقة المعطيات: بديل للبحث الخطّي. المطلوب: الفكرة. الحل: الخطوة 1: نحدّد نصف قطر ثمّ نقلّل نموذجاً تربيعيّاً داخله. النتيجة: أكثر متانة في غير المحدّب. الربط بالذكاء الاصطناعي: Levenberg–Marquardt (7.11).

مثال (20.6-13): فشل البحث الخطّي المعطيات: لا يوجد η يحقّق الشروط. المطلوب: الأسباب. الحل: الخطوة 1: d ليس هبوطاً، أو دقّة عددية. النتيجة: تراجع الاتجاه/التدرّج. الربط بالذكاء الاصطناعي: تصحيح أخطاء التدريب.

مثال (20.6-14): بحث غير رتيب المعطيات: نسمح بزيادة مؤقّتة. المطلوب: الفائدة. الحل: الخطوة 1: يفيد في المشاهد الوعرة. (non-monotone) النتيجة: هروب من سروج ضحلة. الربط بالذكاء الاصطناعي: محسّنات التعلّم العميق.

مثال (20.6-15): البحث في المكتبات المعطيات: L-BFGS في scipy. المطلوب: الملاحظة. الحل: الخطوة 1: يستخدم وولف القوي افتراضيّاً. النتيجة: قويّ وجاهز. الربط بالذكاء الاصطناعي: أدوات الإنتاج.

أخطاء شائعة

- استخدام اتجاه ليس هبوطاً في البحث الخطّي.
- نسيان شرط وولف فيقصر التقدّم.
- الخلط بين c_1 (نقصان) و c_2 (انحناء).
- الاعتماد على بحث خطّي مع تدرّج صاخب (SGD) — غير مناسب.

(20.6)

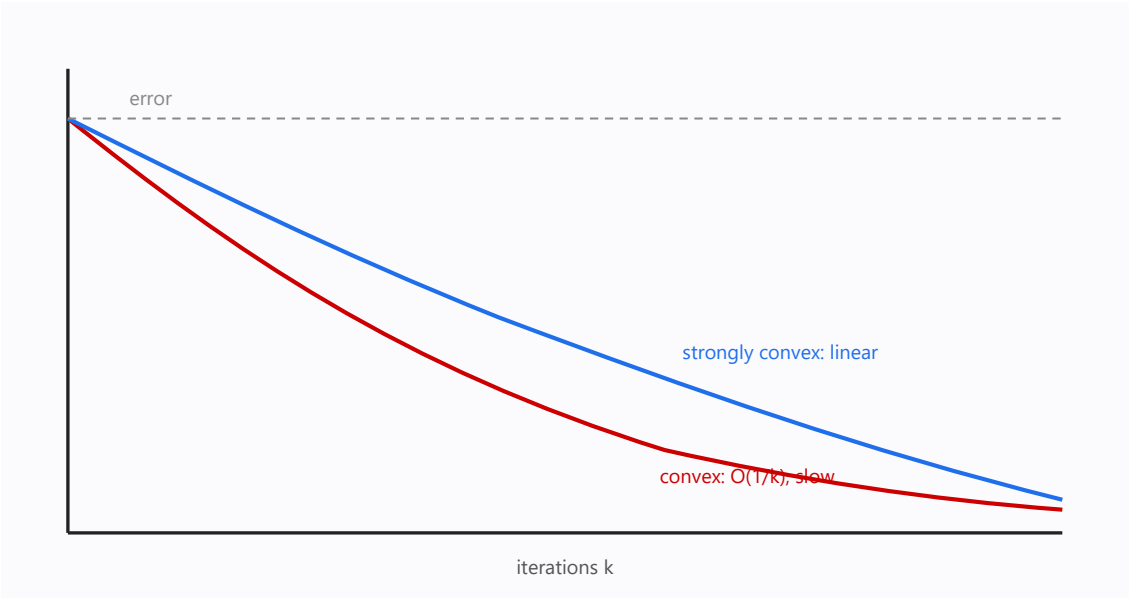
$$f(x_k)-f^\star = O(1/k), \qquad \text{محدّب:} \qquad f(x_k)-f^\star \le \left(1-\frac{\mu}{L}\right)^k (f(x_0)-f^\star) \qquad \text{قوي التحدّب:} \qquad x_{k+1} = x_k - \eta \nabla f(x_k),$$

جدول الرموز

الرمز	المعنى
η	معدّل التعلّم
$O(1/k)$	تقارب دون خطّي (محدّب)
$(1-\mu/L)^k$	تقارب خطّي (قوي التحدّب)

الرسم

<figure>
الشكل 20.6: محدّب $O(1/k)$ ⇒ قوي التحدّب ⇒ تضاؤل أسّي بمعامل $1-\mu/L$.
</figure>



شكل ٦.٢٠: *
معدلات تقارب هبوط التدرج

البرهان (مخطّط)

من متراجحة الهبوط $f(x_{k+1}) \leq f(x_k) - \eta(1 - \frac{\eta L}{2})\|\nabla f\|^2$ نجمع ونقسم على التحدّب القوي $\|\nabla f\|^2 \geq 2\mu(f - f^\star)$ (متراجحة PL) فنحصل على التضاؤل الأسّي بـ $\eta = 1/L$. بدون تحدّب قوي نجمع على $\|\nabla f\|$ لنحصل على $O(1/k)$. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.20): تكرار الهبوط المعطيات: $f = x^2$، $\eta = 0.1$، $x_0 = 1$. المطلوب: x_1. الحل: الخطوة 1: $\nabla f = 2x = 2 \Rightarrow x_1 = 1 - 0.1(2) = 0.8$. النتيجة: $x_1 = 0.8$. الربط بالذكاء الاصطناعي: تكرار التحديث الأساسي.

مثال (2-7.20): التقارب للتربيعي المعطيات: $f = x^2$، $\eta = 0.1$. المطلوب: معامل التضاؤل. الحل: الخطوة 1: $|1 - 2\eta| = 0.8$ لكل تكرار. النتيجة: تضاؤل أسّي. الربط بالذكاء الاصطناعي: سرعة التدريب.

مثال (3-7.20): معدّل $O(1/k)$ المعطيات: f محدّبة سلسة فقط. المطلوب: المعدّل. الحل: الخطوة 1: $f(x_k) - f^\star \leq \frac{L\|x_0 - x^\star\|^2}{2k}$. النتيجة: تقارب دون خطّي. الربط بالذكاء الاصطناعي: لماذا التدريب يطول بلا تنظيم.

مثال (4-7.20): المعدّل الخطّي المعطيات: $\mu = 1$، $L = 10$. المطلوب: معامل التكرار. الحل: الخطوة 1: $1 - 0.9^k \Rightarrow \mu/L = 0.9$. النتيجة: تقارب أسرع بكثير. الربط بالذكاء الاصطناعي: أثر التنظيم/التحدّب القوي.

مثال (5-7.20): الخطوة المثلى المعطيات: للتربيعي بـ μ, L. المطلوب: أفضل η. الحل: الخطوة 1: $\eta^\star = \frac{2}{L+\mu}$ (يصغّر معامل التضاؤل). النتيجة: أسرع تقارب. الربط بالذكاء الاصطناعي: ضبط معدّل التعلّم.

مثال (6-7.20): تسريع نيستروف المعطيات: نضيف زخماً بخطوة متقدّمة. المطلوب: المعدّل. الحل: الخطوة 1: $O(1/k^2)$ للمحدّب (مقابل $O(1/k)$). النتيجة: تسريع كبير. الربط بالذكاء الاصطناعي: Adam/Nesterov momentum.

مثال (7-7.20): حدس الزخم المعطيات: كرة تتدحرج. المطلوب: التفسير. الحل: الخطوة 1: تراكم الاتجاهات يخفّف التعرّج في الوادي الضيّق. النتيجة: مسار أنعم. الربط بالذكاء الاصطناعي: محسّنات الزخم.

مثال (20.7-8): ضوضاء SGD المعطيات: نستخدم دفعة صغيرة. المطلوب: الأثر. الحل: الخطوة 1: التدرّج صاخب $\Rightarrow$ نتوقّف عند جوار لا نقطة. النتيجة: نحتاج جدولة معدّل التعلّم (الفصل 22). الربط بالذكاء الاصطناعي: تدريب الشبكات فعليّاً.

مثال (20.7-9): تكرارات إلى ϵ المعطيات: $\kappa = 100$، $\epsilon = 10^{-6}$. المطلوب: التقدير. الحل: الخطوة 1: $k \approx \kappa \ln(1/\epsilon) \approx 100 \times 13.8 = 1380$. النتيجة: ≈ 1380 تكراراً. الربط بالذكاء الاصطناعي: ميزانية الحساب.

مثال (20.7-10): أثر κ الكبير المعطيات: $\kappa = 10^4$. المطلوب: التكرارات. الحل: الخطوة 1: يقفز إلى ≈ 138000. النتيجة: التكييف حاسم. الربط بالذكاء الاصطناعي: تطبيع الميزات/Adam.

مثال (20.7-11): تربيعي رقمي المعطيات: $A = \mathrm{diag}(1, 100)$، $\eta = 0.01$. المطلوب: السلوك. الحل: الخطوة 1: الاتجاه الأول بطيء؛ الثاني سريع/متذبذب. النتيجة: تعرّج واضح. الربط بالذكاء الاصطناعي: أمثلة توضيحية للتدريب.

مثال (20.7-12): دون خطّي مقابل خطّي المعطيات: f بلا تحدّب قوي. المطلوب: الفرق العملي. الحل: الخطوة 1: $O(1/k)$ يعني تحسيناً متضائلاً ببطء. النتيجة: نحتاج تنظيماً أو تسريعاً. الربط بالذكاء الاصطناعي: قرارات هندسية.

مثال (20.7-13): شرط PL $\Rightarrow$ خطّي المعطيات: $\frac{1}{2}\|\nabla f\|^2 \geq \mu(f - f^\star)$ بلا تحدّب. المطلوب: المعدّل. الحل: الخطوة 1: يكفي لتقارب خطّي. النتيجة: يفسّر نجاح غير المحدّب. الربط بالذكاء الاصطناعي: نظرية التعلّم العميق الحديثة.

مثال (20.7-14): قيمة الدالّة مقابل نُرم التدرّج المعطيات: أيّهما معيار توقّف؟ المطلوب: المقارنة. الحل: الخطوة 1: $\|\nabla f\| \leq \epsilon$ شائع؛ $f - f^\star$ يحتاج معرفة $f^\star$. النتيجة: نستخدم نُرم التدرّج. الربط بالذكاء الاصطناعي: early stopping عملي.

مثال (20.7-15): معيار التوقّف العملي المعطيات: تدريب شبكة. المطلوب: المعيار. الحل: الخطوة 1: $\|\nabla f\|$ صغير أو تحسّن التحقّق توقّف. النتيجة: توقّف مبكّر. الربط بالذكاء الاصطناعي: منع الإفراط في التعلّم.

أخطاء شائعة

- استخدام η ثابت أكبر من $2/L \Rightarrow$ تباعد.
- توقّع تقارب خطّي في غير قوي التحدّب.
- نسيان أن $O(1/k)$ للمحدّب يحتاج متوسطاً/تراكماً.
- الخلط بين تقارب قيمة الدالّة وتقارب المتغيّر.

نيوتن: بتقليل نموذج تايلور الثاني نحصل على

$$x_{k+1} = x_k - \left(\nabla^2 f(x_k)\right)^{-1} \nabla f(x_k), \qquad \textbf{BFGS:} B_{k+1} = B_k - \frac{B_k s_k s_k^\top B_k}{s_k^\top B_k s_k} + \frac{y_k y_k^\top}{y_k^\top s_k} \tag{20.7}$$

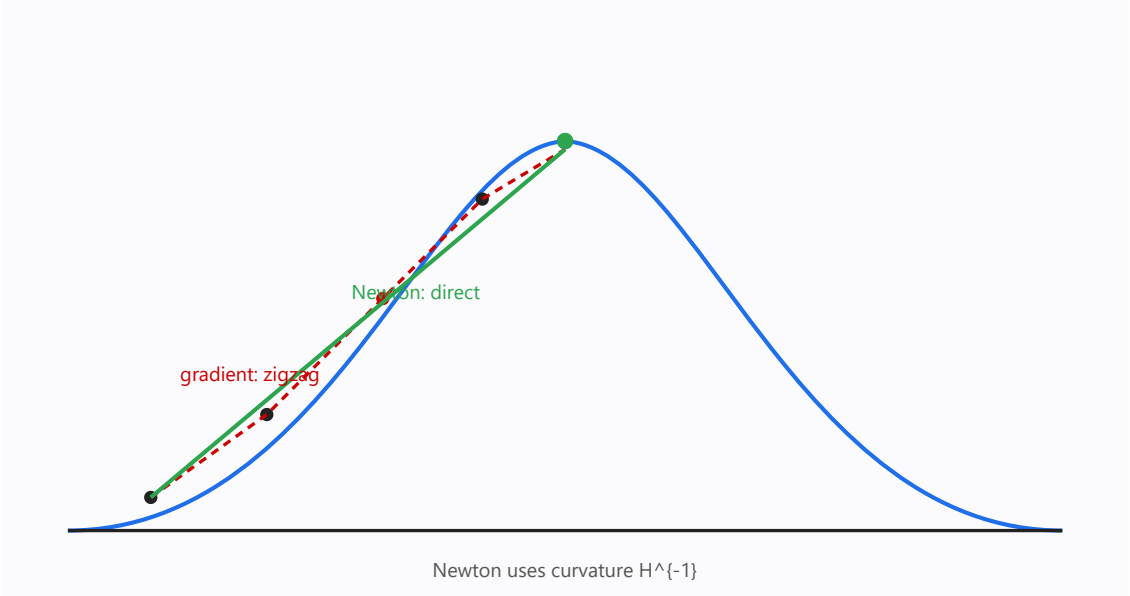
حيث $s_k = x_{k+1} - x_k$ و $y_k = \nabla f_{k+1} - \nabla f_k$.

جدول الرموز

الرمز	المعنى
$H^{-1}\nabla f$	خطوة نيوتن
B_k	تقدير الهسّية (أو معكوسها)
s_k, y_k	فرق الموضع وفرق التدرّج
معادلة القاطع	$B_{k+1} s_k = y_k$

الرسم

<figure> الشكل<figcaption> 7.20: نيوتن يستخدم الانحناء فيقفز مباشرة نحو القاع؛ هبوط التدرّج



شكل ٧.٢٠: *
نيوتن مقابل هبوط التدرج

يتعرّج.</figcaption> </figure>

البرهان (مخطّط)

نموذج تايلور $m(d) = f + \nabla f^\top d + \tfrac{1}{2} d^\top H d$؛ بتصفير تدرّجه $Hd = -\nabla f$ نحصل على خطوة نيوتن. BFGS يُشتقّ من إرضاء معادلة القاطع $B_{k+1} s_k = y_k$ مع تحديث رتبة-2 يحفظ التحديد الإيجابي. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.20): اشتقاق خطوة نيوتن المعطيات: $m(d) = f + \nabla f^\top d + \tfrac{1}{2} d^\top H d$. المطلوب: $d^\star$. الحل: الخطوة 1: $\nabla m = Hd + \nabla f = 0$. النتيجة: $d = -H^{-1}\nabla f$. الربط بالذكاء الاصطناعي: أساس طرق الرتبة الثانية.

مثال (2-8.20): نيوتن للتربيعي بخطوة واحدة المعطيات: $f = \tfrac{1}{2} x^\top A x - b^\top x$. المطلوب: عدد الخطوات. الحل: الخطوة 1: $H = A$ ثابت؛ $x_1 = x_0 - A^{-1}(Ax_0 - b) = A^{-1} b$. النتيجة: خطوة واحدة تكفي. الربط بالذكاء الاصطناعي: لماذا نيوتن قويّ للتربيعي.

مثال (3-8.20): تقارب تربيعي المعطيات: قرب $x^\star$ و $H \succ 0$. المطلوب: المعدّل. الحل: الخطوة 1: $\|x_{k+1} - x^\star\| \le C \|x_k - x^\star\|^2$. النتيجة: تضاعف الأرقام الصحيحة. الربط بالذكاء الاصطناعي: دقّة عالية بسرعة.

مثال (4-8.20): نيوتن يحتاج هِسّية موجبة المعطيات: H غير محدّدة (سرج). المطلوب: المشكلة. الحل: الخطوة 1: الخطوة قد تصعد الدالّة. النتيجة: نعدّل $H + \lambda I$ أو منطقة ثقة. الربط بالذكاء الاصطناعي: Levenberg–Marquardt.

مثال (5-8.20): نيوتن مخفّف المعطيات: نضيف بحثاً خطّياً لنيوتن. المطلوب: الفائدة. الحل: الخطوة 1: يضمن هبوطاً كافياً حتى بعيداً عن الحلّ. النتيجة: متانة عالمية. الربط بالذكاء الاصطناعي: تنفيذ آمن.

مثال (6-8.20): تكلفة نيوتن المعطيات: n مليون معلمة. المطلوب: التكلفة. الحل: الخطوة 1: حساب H وتحليله $O(n^3)$ وذاكرة $O(n^2)$. النتيجة: غير ممكن للشبكات الضخمة. الربط بالذكاء الاصطناعي: لماذا نستخدم الرتبة الأولى.

مثال (20.8-7): BFGS المعطيات: لا نريد حساب H. المطلوب: البديل. الحل: الخطوة 1: نقدّر H (أو معكوسها) من فروق التدرّج. النتيجة: تحديث رتبة-2 رخيص. الربط بالذكاء الاصطناعي: محسّن شائع في scipy.

مثال (20.8-8): L-BFGS ذاكرة محدودة المعطيات: n ضخم. المطلوب: الحلّ. الحل: الخطوة 1: نخزّن آخر m أزواج (s, y) فقط (عادة $m \approx 10$). النتيجة: تكلفة $O(mn)$ لكل تكرار. الربط بالذكاء الاصطناعي: تدريب نماذج متوسّطة/كبيرة.

مثال (20.8-9): معادلة القاطع المعطيات: $B_{k+1}s_k = y_k$. المطلوب: المعنى. الحل: الخطوة 1: التقدير يطابق التغيّر الفعلي للتدرّج. النتيجة: شرط أساسي لتحديث شبه نيوتن. الربط بالذكاء الاصطناعي: التحقّق من صحة التنفيذ.

مثال (20.8-10): نيوتن لا يتأثّر بالتكييف المعطيات: تغيير متغيّرات خطّي. المطلوب: الخاصّية. الحل: الخطوة 1: نيوتن ثابت تحويلاً تآلفياً (affine invariant). النتيجة: لا يعاني من κ الكبير. الربط بالذكاء الاصطناعي: متانة مقابل سوء التكييف.

مثال (20.8-11): نيوتن- CG بدون هِسّية صريحة المعطيات: نحتاج $H^{-1}\nabla f$ فقط. المطلوب: الطريقة. الحل: الخطوة 1: نحلّ $Hd = -\nabla f$ بالتدرّج المترافق بضربات هِسّية. النتيجة: بلا تخزين H. الربط بالذكاء الاصطناعي: Hessian-free optimization.

مثال (20.8-12): غاوس–نيوتن المعطيات: $f = \frac{1}{2}\|r(x)\|^2$. المطلوب: التقريب. الحل: الخطوة 1: $H \approx J^\top J$ (من 20.7) $\Rightarrow$ نتجنّب الرتبة الثانية. النتيجة: فعّال للمربّعات غير الخطّية. الربط بالذكاء الاصطناعي: تدريب شبكات بخسارة MSE.

مثال (20.8-13): التدرّج الطبيعي المعطيات: فيشر كمقرّب للهِسّية. المطلوب: العلاقة. الحل: الخطوة 1: $F = \mathbb{E}[\nabla \log p \, \nabla \log p^\top]$ (من 20.7) $\Rightarrow$ خطوة $F^{-1}\nabla f$. النتيجة: تحديث ثابت توزيعياً. الربط بالذكاء الاصطناعي: Natural Gradient/هندسة المعلومات.

مثال (20.8-14): متى يفشل نيوتن المعطيات: غير محدّب بسروج. المطلوب: المخاطر. الحل: الخطوة 1: قد يتّجه للسرج أو يتباعد. النتيجة: نحتاج تعديلاً/منطقة ثقة. الربط بالذكاء الاصطناعي: تحسين الشبكات غير المحدّب.

مثال (20.8-15): الاختيار العملي المعطيات: نموذج كبير جدّاً. المطلوب: المحسّن. الحل: الخطوة 1: Adam/AdamW (رتبة أولى تكييفي) هو المعيار. الخطوة 2: L-BFGS للنماذج المتوسّطة/الدقيقة. النتيجة: دليل الاختيار. الربط بالذكاء الاصطناعي: ممارسة التدريب الحديثة.

أخطاء شائعة

- تطبيق نيوتن بلا فحص تحديد الهِسّية الإيجابي.
- نسيان تكلفة $O(n^3)$ فيفضح الحجم.
- خلط BFGS (يقدّر الهِسّية) بصيغة معكوسها (تحديث مختلف).
- استخدام BFGS مع تدرّجات صاخبة (تفشل معادلة القاطع).

ملخّص النظريات

النظرية	المفهوم	الأهمّية في الذكاء الاصطناعي
2.20 الرتبة الأولى	$\nabla f(x^\star)=0$	شرط توقّف التدريب
3.20 الرتبة الثانية	$\nabla^2 f \succ 0$	فصل الأصغرى عن السرج
4.20 التحدّب	محدّب + حرج $\Rightarrow$ عالمي	ضمان اللوجستي/الخطّي
5.20 السلاسة/القوي	$\kappa = L/\mu$، $\mu I \preccurlyeq H \preccurlyeq LI$	يحدّد الصعوبة ومعدّل التعلّم
6.20 البحث الخطّي	أرميخو/وولف	اختيار طول الخطوة
7.20 الهبوط	$O(1/k)$ محدّب، $(1-\mu/L)^k$ قوي	ميزانية التكرارات
8.20 نيوتن/BFGS	$H^{-1}\nabla f$، تحديث القاطع	دقّة عالية/تكلفة أعلى

عشرون تمريناً (مع إجابات مختصرة)

١. اذكر شرط فيرما. $(\nabla f(x^\star)=0)$

٢. هل $\nabla f = 0$ كافٍ للأصغرى؟ (لا؛ قد يكون سرجاً)

٣. مثال مضادّ للرتبة الثانية. (x^4 عند 0)

٤. متى تكون النقطة الحرجة عالمية؟ (عند التحدّب)

٥. عبّر عن التحدّب بالرتبة الثانية. ($\nabla^2 f \succcurlyeq 0$ everywhere)

٦. هل $|x|$ محدّبة؟ (نعم، غير سلسة)

٧. عرّف L-السلاسة. ($\|\nabla f(x)-\nabla f(y)\| \le L\|x-y\|$)

٨. عرّف μ-التحدّب القوي. (زيادة $\frac{\mu}{2}\|y-x\|^2$)

٩. احسب κ بـ $L=50, \mu=2$. (25)

١٠. أكبر خطوة آمنة بـ $L=20$. ($\eta \le 0.1$)

١١. اكتب شرط أرميخو. ($f(x+\eta d) \le f(x) + c_1\eta\nabla f^\top d$)

١٢. ما فائدة شرط وولف؟ (يمنع الخطوات القصيرة جدّاً)

١٣. معدّل الهبوط للمحدّب. ($O(1/k)$)

١٤. معدّله لقوي التحدّب. ($(1-\mu/L)^k$)

١٥. أفضل η للتربيعي. ($2/(L+\mu)$)

١٦. اكتب خطوة نيوتن. ($-H^{-1}\nabla f$)

١٧. كم خطوة لنيوتن على التربيعي؟ (واحدة)

١٨. اكتب معادلة القاطع. ($B_{k+1}s_k = y_k$)

١٩. لماذا L-BFGS أرخص؟ (يخزّن m أزواجاً فقط)

٢٠. متى نفضّل Adam؟ (نماذج ضخمة/تدرّجات صاخبة)

فهرس الرموز

الرمز	المعنى
$x^\star, f^\star$	النقطة والقيمة المثلى
$\nabla f, \nabla^2 f$	التدرّج والهِسّية
L, μ, κ	السلاسة، التحدّب القوي، رقم الحالة
η, d	طول الخطوة والاتجاه
c_1, c_2	ثوابت أرميخو وولف
B, s, y	تقدير الهِسّية وفرق الموضع والتدرّج

مراجع

- Wright & Nocedal — *Optimization Numerical*.
- Vandenberghe & Boyd — *Optimization Convex*.
- Bertsekas — *Programming Nonlinear*.
- Polyak — *Optimization to Introduction*.
- Bottou, Curtis & Nocedal — «Optimization for Methods Large-Scale» ML (صلة: SGD).

خاتمة: هذا الفصل يؤسّس لغة الجزء الرابع. الفصل 21 ينقلنا إلى **التحسين المقيّد** (KKT والثنائية)، ثمّ 22 إلى المحسّنات العشوائية، و 23 إلى طرق هندسة المعلومات.

التحسين المقيّد: KKT والثنائية

«القيود ليست عائقاً عن الحلّ؛ إنّها ما يعطي الحلّ معناه.»

في الفصل العشرين تعاملنا مع تحسين غير مقيّد: نبحث عن نقطة يصفُر عندها التدرّج. لكنّ الواقع مليء بالقيود: أوزان يجب أن تبقى في صندوق، احتمالات يجب أن تجمع إلى واحد، موارد محدودة، ومتطلّبات أمان لا تُخالف. هذا الفصل يعالجها.

سبع نظريات:

- **2.21 مضاعفات لاغرانج** — القيود المساواة.
- **3.21 شروط KKT** — القيود اللامساواة والركود المكمّل.
- **4.21 الثنائية اللاغرانجية** — الدالّة الثنائية.
- **5.21 الثنائية الضعيفة والقوية وسلاتر** — متى تنعدم الفجوة؟
- **6.21 الإسقاط والتدرّج المسقوط** — البقاء داخل مجموعة محدّبة.
- **7.21 العقوبة ولاغرانج المعزّز** — تحويل المقيّد إلى غير مقيّد.
- **8.21 التطبيقات** — SVM والهامش والبرمجة التربيعية.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

المسألة القياسية (primal):

$$\min_{x} f(x) \quad \text{s.t.} \quad h_j(x) = 0 \ (j = 1..m), \qquad g_i(x) \le 0 \ (i = 1..p)$$

الرمز	المعنى
f	الهدف
h_j	قيود المساواة
g_i	قيود اللامساواة
λ_j	مضاعفات المساواة (إشارة حرّة)
μ_i	مضاعفات اللامساواة (≥ 0)
$p^\star, d^\star$	القيمتان المثليتان الأولى والثنائية

عند نقطة مثلى $x^\star$ منتظمة (أي ∇h_j مستقلّة)، يوجد $\lambda \in \mathbb{R}^m$ بحيث:

$$\nabla f(x^\star) + \sum_{j=1}^{m} \lambda_j \, \nabla h_j(x^\star) = 0, \qquad h_j(x^\star) = 0 \tag{1.21}$$

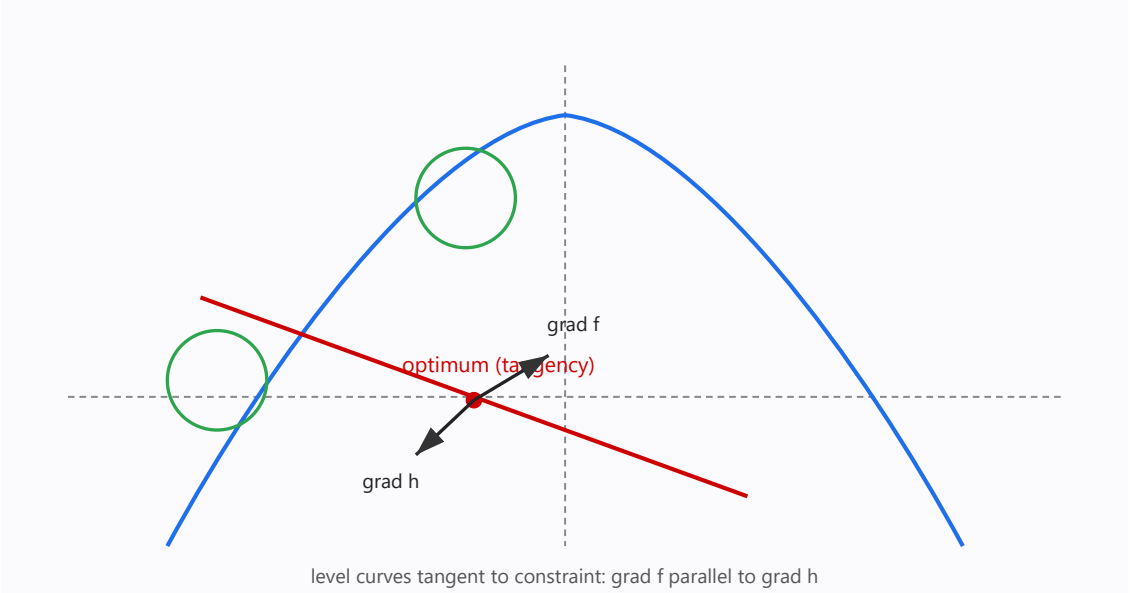
أي أنّ تدرّج الهدف يقع في فضاء تدرّجات القيود.

جدول الرموز

الرمز	المعنى
λ_j	مضاعف لاغرانج
∇h_j	عمودي على سطح القيد
منتظمة	تأهّل القيد (LICQ)

الرسم

<figure> الشكل<figcaption> 1.21: عند الحلّ يماسّ منحنى المستوى سطح القيد؛ التدرّجان متوازيان.</figcaption/>



شكل ١.٢١: *
مضاعفات لاغرانج: تماس منحنيات المستوى مع سطح القيد

</figure>

البرهان (مخطّط)

على منحنى $x(t)$ يسير داخل سطح القيد، الدالّة $\phi(t) = f(x(t))$ لها أصغرى عند $t=0$، فـ $\nabla f^{\top} x'(0) = 0$ لكلّ اتجاه مماسّ. إذن ∇f عمودي على فضاء المماسّ، وهو فضاء تولّده ∇h_j (بشرط الانتظام)، فـ $\nabla f \in \operatorname{span}\{\nabla h_j\}$ أي (1.21). ■

خمسة عشر مثالاً محلولاً

مثال (1-2.21): أصغر مسافة من نقطة المعطيات: $\min x^2+y^2$ بشرط $x+y=1$. المطلوب: الحلّ. الحل: الخطوة 1: $\mathcal{L} = x^2+y^2+\lambda(x+y-1)$. الخطوة 2: $\partial_x = 2x+\lambda = 0$، $\partial_y = 2y+\lambda = 0 \Rightarrow x=y$. الخطوة 3: $x=y=0.5 \Rightarrow 2x=1$، $\lambda=-1$. النتيجة: $(0.5, 0.5)$، مسافة $^2 = 0.5$. الربط بالذكاء الاصطناعي: أقرب نقطة على مستوٍ فائق (projection).

مثال (2-2.21): التفسير الهندسي المعطيات: دوائر متّحدة المركز وسطر قيد. المطلوب: أين الحلّ؟ الحل: الخطوة 1: عند التماسّ، أي تدرّج الهدف يوازي تدرّج القيد. النتيجة: شرط التوازي. الربط بالذكاء الاصطناعي: حدس بصري لشرط لاغرانج.

مثال (21.2-3): مستطيل بمحيط ثابت المعطيات: أعظم مساحة بمحيط P. المطلوب: الأبعاد. الحل: الخطوة 1: $\max ab$ بشرط $2(a+b)=P$. الخطوة 2: $b+\lambda 2=0$، $a+\lambda 2=0 \Rightarrow a=b$. النتيجة: مربّع. الربط بالذكاء الاصطناعي: توزيع متساوٍ تحت قيد إجمالي.

مثال (21.2-4): أعظم إنتروبيا المعطيات: $\max -\sum p_i \log p_i$ بشرط $\sum p_i = 1$ و $\sum p_i x_i = m$. المطلوب: الشكل. الحل: الخطوة 1: المشتقّة تعطي $\log p_i + 1 + \alpha + \beta x_i = 0$. الخطوة 2: $p_i \propto e^{-\beta x_i}$. النتيجة: توزيع أسّي (Gibbs). الربط بالذكاء الاصطناعي: القيود/softmax اللحظية في النماذج التوليدية.

مثال (21.2-5): λ حسّاسية المعطيات: نغيّر القيد $h = c$ إلى $c+\delta$. المطلوب: أثر القيمة المثلى. الحل: الخطوة 1: $\frac{dp^\star}{dc} = -\lambda$. النتيجة: λ «سعر ظلّ» للقيد. الربط بالذكاء الاصطناعي: تحليل حسّاسية الميزانيات/الموارد.

مثال (21.2-6): حلّ بأقلّ نُرم المعطيات: $\min \|x\|^2$ بشرط $Ax = b$. المطلوب: الحلّ. الحل: الخطوة 1: $2x + A^\top \lambda = 0 \Rightarrow x = -\frac{1}{2}A^\top \lambda$. الخطوة 2: بالتعويض $-\frac{1}{2}AA^\top \lambda = b \Rightarrow \lambda$ ثمّ $x = A^\top (AA^\top)^{-1} b$. النتيجة: أصغر نُرم حلّ. (pseudo-inverse) الربط بالذكاء الاصطناعي: least-norm في النماذج غير محدّدة.

مثال (21.2-7): ريدج كلاغرانج المعطيات: $\min \|Xw - y\|^2$ بشرط $\|w\|^2 \le t$. المطلوب: العلاقة. الحل: الخطوة 1: لاغرانج يعطي $\|Xw-y\|^2 + \lambda(\|w\|^2 - t)$. الخطوة 2: يكافئ ريدج معامل λ (من 3.18). النتيجة: التنظيم = قيد على النُرم. الربط بالذكاء الاصطناعي: regularization L2 تفسير مقيّد.

مثال (21.2-8): قيدان المعطيات: $\min x^2 + y^2 + z^2$ بشرط $x + y = 1$ و $y + z = 0$. المطلوب: النظام. الحل: الخطوة 1: $\mathcal{L}$ بـ λ_1, λ_2. الخطوة 2: ثلاث معادلات + قيدين $\Rightarrow$ حلّ فريد. النتيجة: نظام 5×5. الربط بالذكاء الاصطناعي: قيود موارد متعدّدة.

مثال (21.2-9): التوازي المعطيات: $\nabla f = (2,2)$، $\nabla h = (1,1)$. المطلوب: هل الحلّ؟ الحل: الخطوة 1: $\nabla f = 2\nabla h \Rightarrow$ متوازيان. النتيجة: نعم (بـ $\lambda = -2$). الربط بالذكاء الاصطناعي: فحص شرط لاغرانج عدديّاً.

مثال (21.2-10): PCA بلاغرانج المعطيات: $\max u^\top \Sigma u$ بشرط $\|u\| = 1$. المطلوب: الحلّ. الحل: الخطوة 1: $2\Sigma u - 2\lambda u = 0 \Rightarrow \Sigma u = \lambda u$. النتيجة: المتّجه الذاتي الأكبر (من الفصل 4). الربط بالذكاء الاصطناعي: PCA كمسألة مقيّدة.

مثال (21.2-11): محفظة استثمارية المعطيات: $\min w^\top \Sigma w$ بشرط $\sum w_i = 1$. المطلوب: الحلّ. الحل: الخطوة 1: $2\Sigma w + \lambda \mathbf{1} = 0 \Rightarrow w \propto \Sigma^{-1}\mathbf{1}$. النتيجة: محفظة أدنى تباين. الربط بالذكاء الاصطناعي: تخصيص موارد/مخاطر.

مثال (21.2-12): حلّ عددي المعطيات: نظام لاغرانج غير خطّي. المطلوب: الطريقة. الحل: الخطوة 1: نيوتن على النظام (x, λ) معاً. النتيجة: حلّ متزامن. الربط بالذكاء الاصطناعي: محلّلات SQP/القيود.

مثال (21.2-13): قيد منحطّ المعطيات: $\nabla h(x^\star) = 0$. المطلوب: المشكلة. الحل: الخطوة 1: تأهّل القيد يفشل $\Rightarrow$ قد لا يوجد λ. النتيجة: نحتاج تأهّلاً. (LICQ) الربط بالذكاء الاصطناعي: حالات شاذّة في النماذج.

مثال (21.2-14): إشارة λ حرّة المعطيات: قيد مساواة. المطلوب: إشارة λ؟ الحل: الخطوة 1: غير مقيّدة (عكس اللامساواة في 3.21). النتيجة: $\lambda \in \mathbb{R}$. الربط بالذكاء الاصطناعي: الفرق الجوهري بين النوعين.

مثال (21.2-15): MLE بشرط التطبيع المعطيات: نعظّم $\sum n_k \log p_k$ بشرط $\sum p_k = 1$. المطلوب: الحلّ. الحل: الخطوة 1: $\frac{n_k}{p_k} + \lambda = 0 \Rightarrow p_k \propto n_k$. النتيجة: $\hat{p}_k = n_k/n$ (من 2.18). الربط بالذكاء الاصطناعي: تقدير متعدّد الحدود.

أخطاء شائعة

- نسيان أنّ شرط لاغرانج ضروري لا كافٍ (قد يكون عظمى/سرجاً).
- تجاهل تأهّل القيد (LICQ) في حالات الانحطاط.

- فرض إشارة على λ في قيود المساواة (خطأ).
- الخلط بين تعظيم وتقليل في إشارة $\mathcal{L}$.

عند نقطة مثلى منتظمة توجد λ, μ تحقّق أربعة شروط:

$$\nabla f + \sum_j \lambda_j \nabla h_j + \sum_i \mu_i \nabla g_i = 0, \quad \mu_i \geq 0, \quad g_i(x^\star) \leq 0, \quad \mu_i \, g_i(x^\star) = 0 \tag{2.21}$$

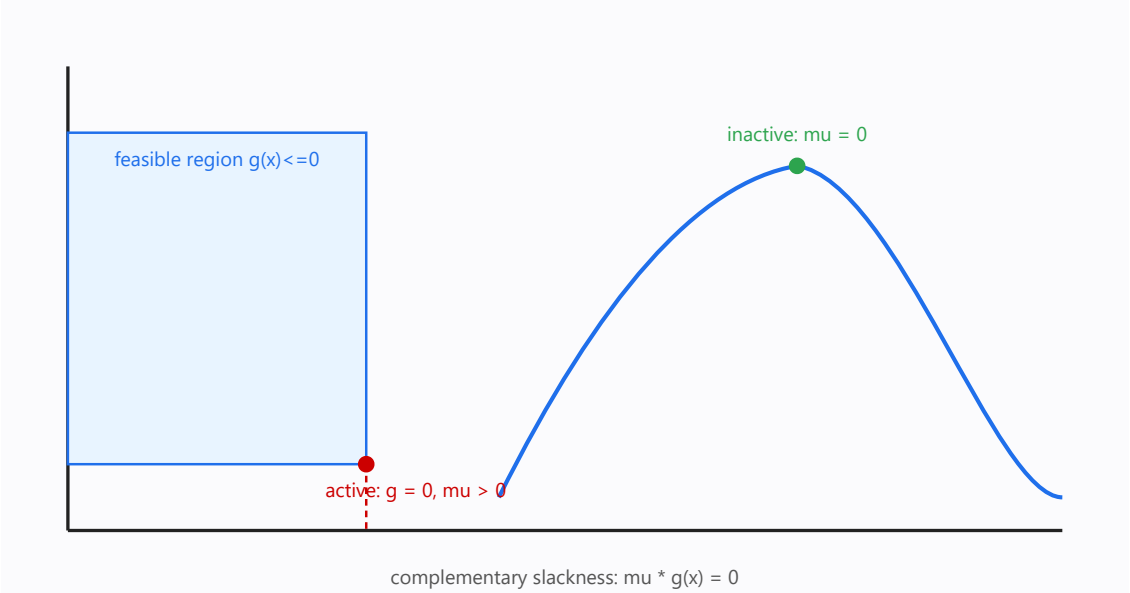
الشرط الأخير هو **الركود المكمِّل** (complementary slackness).

جدول الرموز

الرمز	المعنى
$\mu_i \geq 0$	التحديد الثنائي (dual feasibility)
$g_i \leq 0$	التحديد الأولي (primal feasibility)
$\mu_i g_i = 0$	الركود المكمِّل
$g_i = 0$	قيد نشط

الرسم

<figure> الشكل<figcaption> 2.21: الركود المكمِّل: إمّا القيد غير نشط ($g < 0$، فـ $\mu = 0$) أو نشط ($g = 0$، فـ



شكل ٢.٢١: *
شروط KKT الأربعة

$\mu \geq 0$).</figcaption></figure>

البرهان (مخطّط)

نحوّل كلّ $g_i \leq 0$ إلى $g_i + s_i^2 = 0$ بمتغيّر تراخٍ s_i (slack)؛ بتطبيق لاغرانج نحصل على $\mu_i s_i = 0$ (لأن ∂_{s_i}: $2\mu_i s_i = 0$)، أي $\mu_i g_i = 0$. ومن تعظيم $\mathcal{L}$ على $\mu \geq 0$ تظهر إشارة μ. $\blacksquare$

خمسة عشر مثالاً محلولاً

مثال (21.3-1): قيد بسيط المعطيات: $\min x^2$ بشرط $x \geq 1$. المطلوب: الحلّ بـ KKT. الحل: الخطوة 1: $g = 1 - x \leq 0$، الاستقرارية $2x - \mu = 0$. الخطوة 2: الركود $\mu(1 - x) = 0$؛ إن كان $x > 1$ فـ $\mu = 0 \Rightarrow x = 0$ (غير ممكن). الخطوة 3: إذن $x = 1$، $\mu = 2 \geq 0$ ✓. النتيجة: $x^\star = 1$، القيد نشط. الربط بالذكاء الاصطناعي: صندوق قيم ميزة/وزن.

مثال (21.3-2): قيد غير نشط المعطيات: $\min x^2$ بشرط $x \geq -5$. المطلوب: الحلّ. الحل: الخطوة 1: غير المقيّد يعطي $x = 0$ وهو ممكن. الخطوة 2: $g = -5 - x < 0 \Rightarrow \mu = 0$. النتيجة: $x^\star = 0$، القيد غير نشط. الربط بالذكاء الاصطناعي: القيود التي لا تؤثّر.

مثال (21.3-3): قيد نشط المعطيات: $\min (x-3)^2$ بشرط $x \leq 1$. المطلوب: الحلّ. الحل: الخطوة 1: غير المقيّد $x = 3$ مخالف $\Rightarrow$ القيد نشط. الخطوة 2: $x = 1$، ومن الاستقرارية $2(1-3) + \mu = 0 \Rightarrow \mu = 4 \geq 0$. النتيجة: $x^\star = 1$، $\mu = 4$. الربط بالذكاء الاصطناعي: قيد أمان يقيّد الحلّ.

مثال (21.3-4): الركود المكمّل المعطيات: $\mu = 3$. المطلوب: قيمة g؟ الحل: الخطوة 1: $\mu > 0 \Rightarrow$ يجب $g = 0$. النتيجة: القيد نشط تماماً. الربط بالذكاء الاصطناعي: تحديد القيود الفعّالة.

مثال (21.3-5): التحديد الثنائي المعطيات: وجدنا $\mu = -2$. المطلوب: الحكم. الحل: الخطوة 1: ينتهك $\mu \geq 0 \Rightarrow$ ليست نقطة KKT. النتيجة: نراجع الحلّ/الاتجاه. الربط بالذكاء الاصطناعي: فحص صحّة المحسّنات المقيّدة.

مثال (21.3-6): قيود الصندوق المعطيات: $\min f(x)$ بشرط $l \leq x \leq u$. المطلوب: شروط KKT. الحل: الخطوة 1: قيدان لكلّ إحداثي، نشاط أحدهما على الأكثر. النتيجة: $\mu_l(l - x) = 0$ و $\mu_u(x - u) = 0$. الربط بالذكاء الاصطناعي: قصّ الأوزان/clipping.

مثال (21.3-7): لاسو كقيد المعطيات: $\min \|Xw - y\|^2$ بشرط $\|w\|_1 \leq t$. المطلوب: العلاقة. الحل: الخطوة 1: لاغرانج $\Rightarrow \|Xw - y\|^2 + \lambda \|w\|_1$. النتيجة: لاسو (من 3.18). الربط بالذكاء الاصطناعي: التنظيم L1 صيغة مقيّدة.

مثال (21.3-8): الضرورة تحت LICQ المعطيات: $x^\star$ مثلى ومنتظمة. المطلوب: هل KKT ضروري؟ الحل: الخطوة 1: نعم تحت تأهّل القيد. النتيجة: شرط لازم. الربط بالذكاء الاصطناعي: متى نثق بحلّ المحسّن؟

مثال (21.3-9): الكفاية مع التحدّب المعطيات: f, g_i محدّبة و h تآلفية. المطلوب: هل KKT كافٍ؟ الحل: الخطوة 1: نعم $\Rightarrow$ كلّ نقطة KKT مثلى عالمية. النتيجة: تحسين مضمون. الربط بالذكاء الاصطناعي: SVM/QP مضمونة.

مثال (21.3-10): SVM الأولي المعطيات: $\min \frac{1}{2}\|w\|^2$ بشرط $1 - y_i(w^\top x_i + b) \leq 0$. المطلوب: KKT. الحل: الخطوة 1: $w = \sum \alpha_i y_i x_i$ مع $\alpha_i \geq 0$. الخطوة 2: الركود: $\alpha_i > 0$ فقط للنقاط على الهامش. النتيجة: أشعة الدعم (support vectors). الربط بالذكاء الاصطناعي: SVM (الفصل 30).

مثال (21.3-11): حالة غير ممكنة المعطيات: قيود متناقضة ($x \leq 0$ و $x \geq 1$). المطلوب: النتيجة. الحل: الخطوة 1: لا توجد نقطة ممكنة. النتيجة: المسألة غير ممكنة (infeasible). الربط بالذكاء الاصطناعي: قيود متضاربة في النظام.

مثال (21.3-12): مبسّط الاحتمالات المعطيات: $\min -\sum p_i \log q_i$ بشرط $\sum q_i = 1$، $q_i \geq 0$. المطلوب: الحلّ. الحل: الخطوة 1: KKT يعطي $q_i \propto p_i$. النتيجة: الخسارة الأدنى عند $q = p$. الربط بالذكاء الاصطناعي: تبرير الإنتروبيا المتقاطعة.

مثال (21.3-13): مساواة ولامساواة معاً المعطيات: قيدان من النوعين. المطلوب: النظام. الحل: الخطوة 1: الاستقرارية بكلا المضاعفين + الشروط الثلاثة. النتيجة: نظام كامل. الربط بالذكاء الاصطناعي: مسائل مختلطة في الإنتاج.

مثال (21.3-14): فشل التأهّل المعطيات: $\min x$ بشرط $x^2 \leq 0$. المطلوب: KKT؟ الحل: الخطوة 1: الممكن هو $\{0\}$ فقط، $\nabla g = 0$ عنده $\Rightarrow$ LICQ يفشل. النتيجة: قد لا يوجد μ. الربط بالذكاء الاصطناعي: حالات حدّية نادرة.

مثال (15-3.21): قيد على شبكة المعطيات: تدريب شبكة بشرط $\|w\|_2 \le c$. المطلوب: التنفيذ. الحل: الخطوة 1: إسقاط بعد كلّ خطوة (6.21) أو قصّ النُرم. النتيجة: تدريب مقيّد. الربط بالذكاء الاصطناعي: استقرار التدريب (gradient clipping).

أخطاء شائعة

- نسيان التحديد الثنائي $\mu \ge 0$ عند التقليل.
- الخلط بين نشاط القيد وقيمة μ.
- افتراض KKT كافياً في غير المحدّب (هو ضروري فقط).
- تجاهل تأهّل القيد في الحالات المنحطّة.

الدالّة اللاغرانجية والدالّة الثنائية:

$$\mathcal{L}(x, \lambda, \mu) = f(x) + \sum_j \lambda_j h_j(x) + \sum_i \mu_i g_i(x), \qquad g(\lambda, \mu) = \inf_x \mathcal{L}(x, \lambda, \mu) \tag{3.21}$$

والمسألة الثنائية: $\max_{\mu \ge 0} g(\lambda, \mu)$.

جدول الرموز

الرمز	المعنى
$\mathcal{L}$	اللاغرانجي
$g(\lambda, \mu)$	الدالّة الثنائية
$\inf_x$	التقليل الداخلي
g ثنائية مقعّرة	g مقعّرة دائماً

الرسم

<figure> الشكل<figcaption> 3.21: تقليل اللاغرانجي على x فنحصل على دالّة مقعّرة في المضاعفات نعظّمها.</figcaption> </figure>

البرهان (مخطّط)

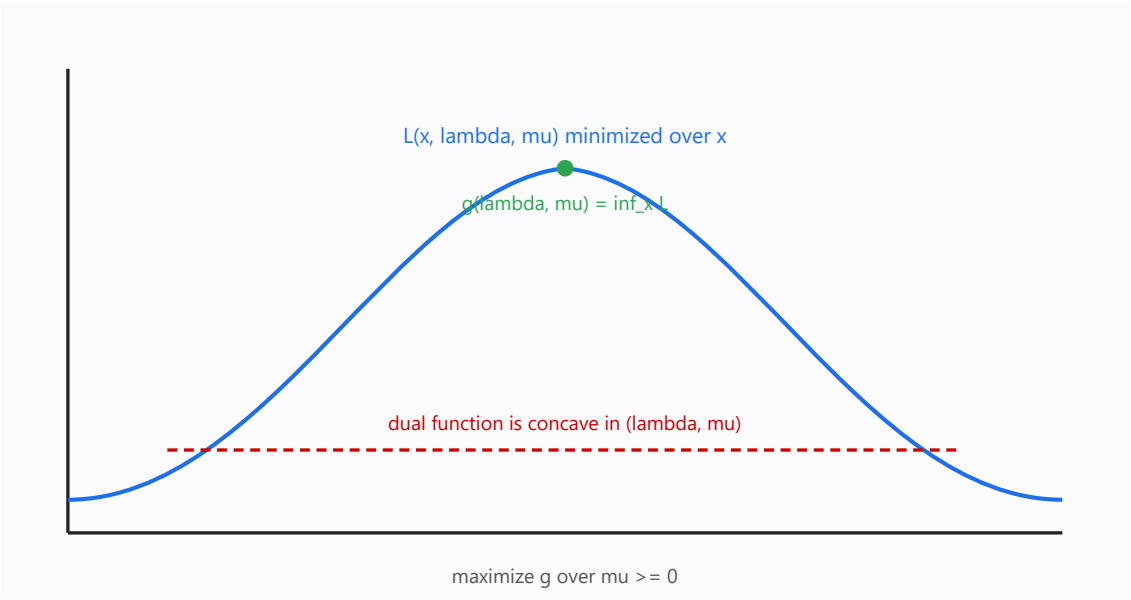
g هي inf على عائلة من الدوالّ التآلفية في (λ, μ)، و inf لتآلفية مقعّرة (من 4.20) $\Rightarrow g$ مقعّرة. لذا تعظيمها مسألة محدّبة مهما كانت المسألة الأولى. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.21): تعريف اللاغرانجي المعطيات: $f = x^2$، $h = x - 1$. المطلوب: $\mathcal{L}$. الحل: الخطوة 1: $\mathcal{L} = x^2 + \lambda(x - 1)$. النتيجة: اللاغرانجي. الربط بالذكاء الاصطناعي: بناء الثنائية لأيّ مسألة.

مثال (2-4.21): الدالّة الثنائية المعطيات: نفس المسألة. المطلوب: $g(\lambda)$. الحل: الخطوة 1: $\partial_x = 2x + \lambda = 0 \Rightarrow x = -\lambda/2$. الخطوة 2: $g = -\lambda^2/4 - \lambda$. النتيجة: $g(\lambda) = -\lambda^2/4 - \lambda$. الربط بالذكاء الاصطناعي: التقليل الداخلي مغلق هنا.

مثال (3-4.21): تقعّر g المعطيات: $g = -\lambda^2/4 - \lambda$. المطلوب: النوع. الحل: الخطوة 1: معامل $-\frac{1}{4} < 0 \Rightarrow$ مقعّرة. النتيجة: تعظيمها سهل. الربط بالذكاء الاصطناعي: لماذا الثنائية جذّابة.



شكل ٢١.٣: *
الثنائية اللاغرانجية: التقليل الداخلي والتعظيم الخارجي

مثال (21.4-4): ثنائية البرنامج الخطّي المعطيات: $\min c^\top x$ بشرط $Ax = b$، $x \geq 0$. المطلوب: الثنائية. الحل: الخطوة 1: g منتهٍ فقط إذا $A^\top \lambda \leq c$. النتيجة: الثنائية الكلاسيكية للبرنامج الخطّي. الربط بالذكاء الاصطناعي: تحسين الموارد/النقل.

مثال (21.4-5): ثنائية QP بالمساواة المعطيات: $\min \frac{1}{2} x^\top Q x$ بشرط $Ax = b$. المطلوب: g. الحل: الخطوة 1: $g = -\frac{1}{2}\lambda^\top A Q^{-1} A^\top \lambda + b^\top \lambda \Rightarrow x = -Q^{-1}A^\top \lambda$. النتيجة: ثنائية تربيعية. الربط بالذكاء الاصطناعي: QP في النماذج.

مثال (21.4-6): ثنائية SVM المعطيات: SVM الأولي. المطلوب: الثنائية. الحل: الخطوة 1: نقلّل على $w, b \Rightarrow \max \sum \alpha_i - \frac{1}{2}\sum \alpha_i \alpha_j y_i y_j x_i^\top x_j$. الخطوة 2: بشرط $\sum \alpha_i y_i = 0$، $0 \leq \alpha_i \leq C$. النتيجة: ثنائية SVM الشهيرة. الربط بالذكاء الاصطناعي: نواة (kernel) تظهر هنا.

مثال (21.4-7): ثنائية ريدج المقيّد المعطيات: $\min \|Xw - y\|^2$ بشرط $\|w\|^2 \leq t$. المطلوب: الثنائية. الحل: الخطوة 1: تصير بمضاعف واحد $\mu \geq 0$. النتيجة: ثنائية بمتغيّر واحد. الربط بالذكاء الاصطناعي: ضبط t مقابل λ.

مثال (21.4-8): تفسير المضاعف المعطيات: μ_i في الحلّ. المطلوب: المعنى. الحل: الخطوة 1: حسّاسية القيمة المثلى لتوسيع القيد. النتيجة: «سعر» تخفيف القيد. الربط بالذكاء الاصطناعي: أيّ قيد يكلفنا أكثر؟

مثال (21.4-9): المعطيات: $g = -\infty$ ($f = x$ خطّية غير محدودة). المطلوب: g. الحل: الخطوة 1: $\inf_x$ غير منتهٍ $\Rightarrow g = -\infty$. النتيجة: المضاعف غير مجدٍ. الربط بالذكاء الاصطناعي: مجال الثنائية مهمّ.

مثال (21.4-10): مجال الثنائية المعطيات: $g(\lambda) > -\infty$. المطلوب: الأهمّية. الحل: الخطوة 1: ذلك يحدّد القيود الثنائية (مثل $A^\top \lambda \leq c$). النتيجة: مجال صالح. الربط بالذكاء الاصطناعي: مجال مضاعفات SVM.

مثال (21.4-11): ثنائية أعظم إنتروبيا المعطيات: من 21.4-2. المطلوب: الثنائية. الحل: الخطوة 1: تعظيم على β يعطي توزيع Gibbs. النتيجة: ثنائية مقعّرة. الربط بالذكاء الاصطناعي: نماذج الطاقة (energy-based models).

مثال (21.4-12): صعود الثنائية المعطيات: نعظّم g بصعود التدرّج. المطلوب: الخوارزمية. الحل: الخطوة 1: نحدّث λ, μ بصعود على g. النتيجة: صعود ثنائي (dual ascent). الربط بالذكاء الاصطناعي: تحسين موزّع.

مثال (21.4-13): ثنائية لاسو المعطيات: $\min \frac{1}{2}\|Xw - y\|^2 + \lambda \|w\|_1$. المطلوب: الثنائية. الحل: الخطوة 1:

تعطي قيداً على $\|X^\top \nu\|_\infty \le \lambda$. النتيجة: ثنائية صندوقية. الربط بالذكاء الاصطناعي: شروط KKT لاختيار الميزات.

مثال (21.4-14): النُرم النووي المعطيات: إكمال مصفوفة بشرط رتبة. المطلوب: الثنائية. الحل: الخطوة 1: الاسترخاء للنُرم النووي $\Rightarrow$ ثنائية محدّبة. النتيجة: حلّ فعال. الربط بالذكاء الاصطناعي: التصفية التعاونية (18.8).

مثال (21.4-15): تحليل موزّع المعطيات: هدف مجموع أجزاء بقيود ربط. المطلوب: الحلّ. الحل: الخطوة 1: الثنائية تفكك المسألة إلى مسائل مستقلّة. النتيجة: تحسين موزّع قابل للتوسعة. الربط بالذكاء الاصطناعي: تعلّم اتحادي (federated).

أخطاء شائعة

- نسيان قيد $\mu \ge 0$ في المسألة الثنائية.
- الخلط بين g (الدالّة الثنائية) و g_i (قيود اللامساواة).
- افتراض أنّ استرجاع الأولى من الثنائية ممكن دائماً (ليس في غير المحدّب).
- تجاهل أنّ g قد تكون $-\infty$ في معظم المجال.

$$d^\star \le p^\star \quad \text{(ضعيفة دائماً)}, \qquad \text{محدّبة + سلاتر} \Rightarrow d^\star = p^\star \quad \text{(قوية)} \tag{4.21}$$

سلاتر: توجد نقطة ممكنة داخليّةStrictly: $g_i(x) < 0$ لكلّ i و $h_j(x) = 0$.

جدول الرموز

الرمز	المعنى
$p^\star$	القيمة المثلى الأولى
$d^\star$	القيمة المثلى الثنائية
$p^\star - d^\star$	فجوة الثنائية
سلاتر	نقطة ممكنة داخلية

الرسم

<figure> الشكل<figcaption> 4.21: الثنائية تحت الأولى دائماً؛ مع التحدّب وسلاتر تتلاشى الفجوة.</figcaption>
</figure>

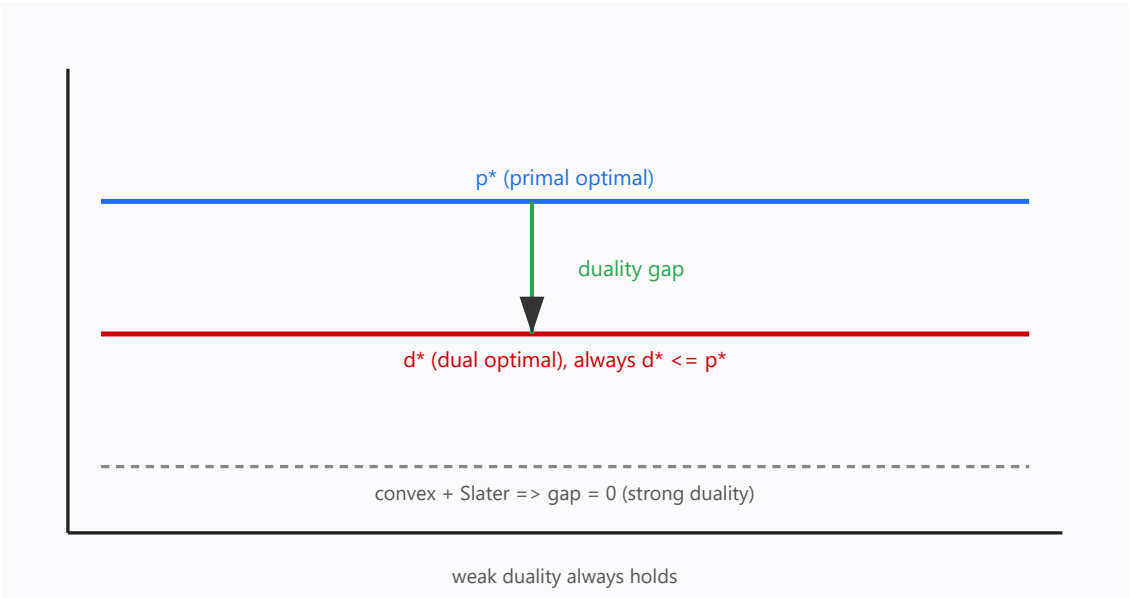
البرهان (مخطّط)

الضعيفة: لأيّ $\mu \ge 0$ ونقطة ممكنة x، $\mathcal{L}(x, \lambda, \mu) \le f(x)$ (لأن $\lambda h = 0$ و $\mu g \le 0$)، ف $g(\lambda, \mu) \le f(x)$؛ بأخذ inf ثمّ sup نحصل على $d^\star \le p^\star$. القوية تحت سلاتر بنظرية فصل المستويات الفائقة للمحدّب. ■

خمسة عشر مثالاً محلولاً

مثال (21.5-1): الثنائية الضعيفة المعطيات: أيّ مسألة. المطلوب: المتراجحة. الحل: الخطوة 1: $g(\lambda, \mu) \le f(x)$ لكلّ x ممكن. النتيجة: $d^\star \le p^\star$. الربط بالذكاء الاصطناعي: حدّ أدنى مضمون على الخسارة.

مثال (21.5-2): فجوة الثنائية المعطيات: $p^\star = 5$، $d^\star = 4$. المطلوب: الفجوة. الحل: الخطوة 1: $5 - 4 = 1$. النتيجة: فجوة موجبة. الربط بالذكاء الاصطناعي: مؤشر عدم تقارب.



شكل ٢١.٤: *
الثنائية الضعيفة والقوية وفجوة الثنائية

مثال (21.5-3): الثنائية القوية المعطيات: مسألة محدّبة + سلاتر. المطلوب: النتيجة. الحل: الخطوة 1: $p^\star = d^\star$. النتيجة: لا فجوة. الربط بالذكاء الاصطناعي: SVM/QP بلا فجوة.

مثال (21.5-4): شرط سلاتر المعطيات: $\min x^2$ بشرط $x \geq 1$. المطلوب: هل يتحقّق؟ الحل: الخطوة 1: النقطة $x = 0$ تحقّق $0 < 1$ داخلياً. النتيجة: نعم. الربط بالذكاء الاصطناعي: تحقّق سريع.

مثال (21.5-5): محدّب + سلاتر $\Rightarrow$ قوية المعطيات: QP محدّب بنقطة داخلية. المطلوب: الحكم. الحل: الخطوة 1: شروط النظرية متحقّقة $\Rightarrow d^\star = p^\star$. النتيجة: ثنائية قوية. الربط بالذكاء الاصطناعي: ضمان نظري.

مثال (21.5-6): غير محدّب بفجوة المعطيات: مسألة صحيحة (integer). المطلوب: الفجوة. الحل: الخطوة 1: المجموعة غير محدّبة $\Rightarrow$ قد تكون الفجوة > 0. النتيجة: فجوة موجبة نموذجاً. الربط بالذكاء الاصطناعي: استرخاء/تقريب في التحسين المتقطّع.

مثال (21.5-7): حساب الفجوة المعطيات: نحسب $p^\star$ و $d^\star$ عددياً. المطلوب: الفجوة. الحل: الخطوة 1: الفرق بين القيمتين من المحسّنَين. النتيجة: رقم محدّد. الربط بالذكاء الاصطناعي: تشخيص الأداء.

مثال (21.5-8): فجوة صفرية $\Rightarrow$ KKT كافٍ المعطيات: $d^\star = p^\star$ ونقطة KKT. المطلوب: الحكم. الحل: الخطوة 1: النقطة مثلى. النتيجة: شهادة أمثلية. الربط بالذكاء الاصطناعي: إثبات صحّة الحلّ.

مثال (21.5-9): نقطة سرجية للاغرانجي المعطيات: $(x^\star, \lambda^\star, \mu^\star)$. المطلوب: الخاصّية. الحل: الخطوة 1: $\mathcal{L}(x, \lambda^\star, \mu^\star) \leq \mathcal{L}(x^\star, \lambda^\star, \mu^\star) \leq \mathcal{L}(x^\star, \lambda, \mu)$. النتيجة: نقطة سرجية. الربط بالذكاء الاصطناعي: منظور اللعبة/الخصم (GAN من 30).

مثال (21.5-10): السرج $\iff$ قوية + KKT المعطيات: نقطة سرجية للاغرانجي. المطلوب: التكافؤ. الحل: الخطوة 1: يكافئ ثنائية قوية مع تحقّق KKT. النتيجة: ربط المفاهيم. الربط بالذكاء الاصطناعي: تحليل النماذج الخصمية.

مثال (21.5-11): LICQ المعطيات: تدرّجات القيود النشطة مستقلّة. المطلوب: الأهمّية. الحل: الخطوة 1: يضمن وجود المضاعفات وتفرّدها. النتيجة: تأهّل قياسي. الربط بالذكاء الاصطناعي: صحّة حلول القيود.

مثال (21.5-12): غير محدّب لا يسترجع الأولى المعطيات: حلّ ثنائي مثلى في غير محدّب. المطلوب: هل يعطي أولياً؟ الحل: الخطوة 1: قد لا؛ نحتاج استرجاعاً أو فجوة صفرية. النتيجة: قيد مهمّ. الربط بالذكاء الاصطناعي: حدود

الطرق الثنائية.

مثال (13-5.21): فشل سلاتر المعطيات: قيد $x^2 \le 0$ (نقطة ممكنة واحدة). المطلوب: النتيجة. الحل: الخطوة 1: لا نقطة داخلية $\Rightarrow$ سلاتر يفشل. النتيجة: قد تظهر فجوة حتى في المحدّب. الربط بالذكاء الاصطناعي: حالات حدّية.

مثال (14-5.21): شهادة الأمثلية المعطيات: وجدنا أولياً وثنائياً بفجوة ϵ. المطلوب: الاستنتاج. الحل: الخطوة 1: الحلّ ضمن ϵ من الأمثلية. النتيجة: ضمان كمّي. الربط بالذكاء الاصطناعي: تقارير موثوقة.

مثال (15-5.21): معيار توقّف بالفجوة المعطيات: محسّن مقيّد. المطلوب: متى نتوقّف؟ الحل: الخطوة 1: عندما $p - d \le \epsilon$. النتيجة: توقّف مبرّر نظرياً. الربط بالذكاء الاصطناعي: جودة التدريب المقيّد.

أخطاء شائعة

- افتراض ثنائية قوية في غير المحدّب.
- نسيان أنّ سلاتر يحتاج نقطة داخلية صارمة.
- استخدام الفجوة مع مضاعفات غير ممكنة ($\mu < 0$).
- الخلط بين الفجوة المطلقة والنسبية في معيار التوقّف.

الإسقاط على مجموعة محدّبة مغلقة C:

$$\Pi_C(z) = \arg\min_{x \in C} \|x - z\|^2, \qquad x_{k+1} = \Pi_C\big(x_k - \eta \nabla f(x_k)\big) \tag{5.21}$$

جدول الرموز

الرمز	المعنى
Π_C	مؤثّر الإسقاط
C	مجموعة محدّبة مغلقة
مسقوط	خطوة تدرّج ثمّ إسقاط

الرسم

<figure> الشكل 5.21: نخطو مع التدرّج ثمّ نعيد النقطة إلى C بأقرب نقطة (الإسقاط المتعامد). </figure>

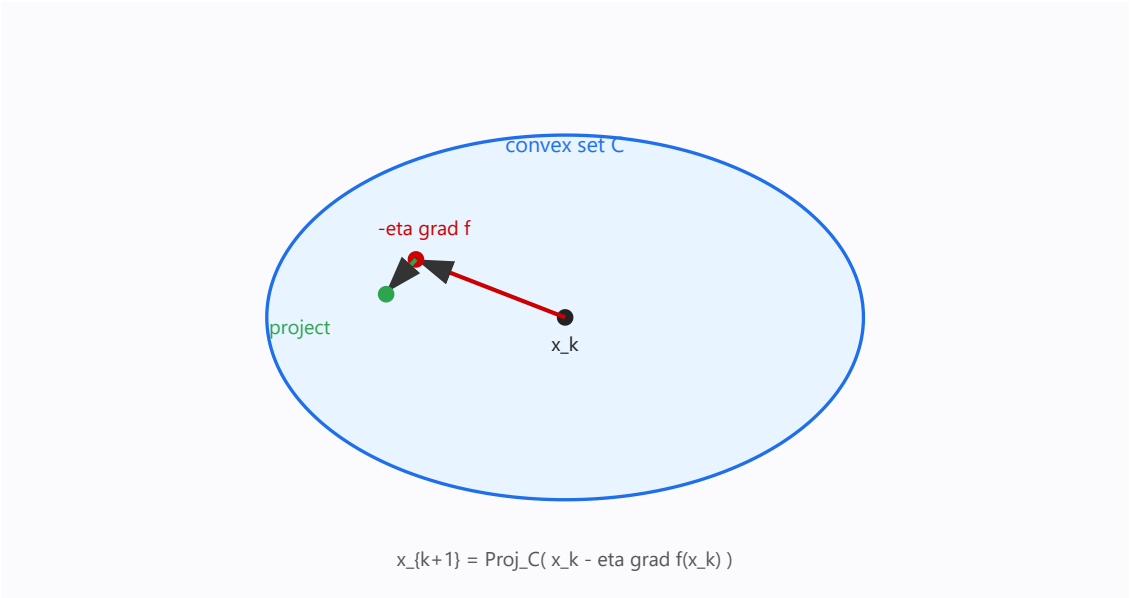
البرهان (مخطّط)

الإسقاط موجود وفريد لمجموعة محدّبة مغلقة (بالمبرهنة الإسقاطية: $(z - \Pi_C z)^\top (x - \Pi_C z) \le 0$ لكلّ $x \in C$). التدرّج المسقوط يتقارب بـ $O(1/k)$ للمحدّب السلس بخطوة $\eta \le 1/L$ (بناءً على 7.20 مع عدم تمدّد الإسقاط). ■

خمسة عشر مثالاً محلولاً

مثال (1-6.21): تعريف الإسقاط المعطيات: $z = (3, 4)$، C قرص وحدة. المطلوب: $\Pi_C(z)$. الحل: الخطوة 1: $\|z\| = 5 > 1 \Rightarrow$ نقسّم: $(0.6, 0.8)$. النتيجة: أقرب نقطة على القرص. الربط بالذكاء الاصطناعي: قصّ نُرم الأوزان (gradient clipping).

مثال (2-6.21): إسقاط على صندوق المعطيات: $C = [0,1]^n$. المطلوب: الصيغة. الحل: الخطوة 1: إحداثياً $\min(1, \max(0, z_i))$ (قصّ). النتيجة: إسقاط بسيط. الربط بالذكاء الاصطناعي: قيود قيم البكسل/الاحتمالات.



شكل ٢١٠٥: *
الإسقاط على مجموعة محدبة والتدرج المسقوط

مثال (21٠6-3): إسقاط على المبسّط المعطيات: $\sum x_i = 1$، $x_i \geq 0$. المطلوب: الطريقة. الحل: الخطوة 1: نرتّب ونطرح عتبة (خوارزمية معروفة). النتيجة: إسقاط على simplex. الربط بالذكاء الاصطناعي: توزيع احتمالات بعد softmax مقيّد.

مثال (21٠6-4): إسقاط على كرة L2 المعطيات: $\|x\|_2 \leq r$. المطلوب: الصيغة. الحل: الخطوة 1: إن $\|z\| > r$ فـ $rz/\|z\|$ وإلا z. النتيجة: تحجيم. الربط بالذكاء الاصطناعي: قيود نُرم الأوزان/التضمينات.

مثال (21٠6-5): إسقاط على نصف فضاء المعطيات: $a^\top x \leq b$. المطلوب: الصيغة. الحل: الخطوة 1: إن خالف: $z - \frac{a^\top z - b}{\|a\|^2} a$. النتيجة: طرح العمودي. الربط بالذكاء الاصطناعي: قيود خطّية مفردة.

مثال (21٠6-6): إسقاط على فضاء تآلفي المعطيات: $Ax = b$. المطلوب: الصيغة. الحل: الخطوة 1: $z - A^\top (AA^\top)^{-1}(Az - b)$. النتيجة: إسقاط متعامد. الربط بالذكاء الاصطناعي: قيود مساواة خطّية.

مثال (21٠6-7): تكرار التدرّج المسقوط المعطيات: $\eta = 0.1$، C صندوق. المطلوب: التحديث. الحل: الخطوة 1: $y = x - \eta \nabla f$ ثمّ $x_+ = \mathrm{clip}(y, 0, 1)$. النتيجة: بقاء داخل الصندوق. الربط بالذكاء الاصطناعي: تدريب بقيم مقيّدة.

مثال (21٠6-8): معدّل التقارب المعطيات: f محدّبة سلسة. المطلوب: المعدّل. الحل: الخطوة 1: $O(1/k)$ كالهبوط غير المقيّد (من 7.20). النتيجة: نفس الرتبة. الربط بالذكاء الاصطناعي: تحليل التدريب المقيّد.

مثال (21٠6-9): مبرهنة الإسقاط المعطيات: C محدّبة مغلقة. المطلوب: الوجود والفرادة. الحل: الخطوة 1: الهدف قوي التحدّب $\Rightarrow$ حلّ فريد (من 5.20). النتيجة: إسقاط محدّد جيداً. الربط بالذكاء الاصطناعي: أمان التنفيذ.

مثال (21٠6-10): عدم التمدّد المعطيات: x, y عشوائيّان. المطلوب: الخاصّية. الحل: الخطوة 1: $\|\Pi x - \Pi y\| \leq \|x - y\|$. النتيجة: الإسقاط لا يباعد. الربط بالذكاء الاصطناعي: استقرار الخوارزمية.

مثال (21٠6-11): إسقاط على كرة L1 المعطيات: $\|x\|_1 \leq t$. المطلوب: الطريقة. الحل: الخطوة 1: قصّ ناعم (soft-thresholding) بعتبة مناسبة. النتيجة: إسقاط فعال. الربط بالذكاء الاصطناعي: تناثر مقيّد.

مثال (21٠6-12): إسقاط على مخروط PSD المعطيات: مصفوفة متماثلة. المطلوب: الإسقاط على $X \succcurlyeq 0$. الحل: الخطوة 1: نحلّل ذاتياً ونقصّ القيم السالبة إلى صفر. النتيجة: إسقاط طيفي (من 5.15). الربط بالذكاء الاصطناعي: قيود مصفوفة التغاير/النواة.

مثال (21.6-13): وصلة المؤثّر القريب المعطيات: prox بدل الإسقاط. المطلوب: العلاقة. الحل: الخطوة 1: الإسقاط هو prox لمؤشّر المجموعة I_C. النتيجة: تعميم موحّد. الربط بالذكاء الاصطناعي: methods proximal (الفصل 22).

مثال (21.6-14): فرانك–وولف المعطيات: إسقاط مكلف. المطلوب: البديل. الحل: الخطوة 1: نتحرّك نحو رأس يصغّر التقريب الخطّي (بلا إسقاط). النتيجة: طريقة خالية من الإسقاط. الربط بالذكاء الاصطناعي: تحسين على المبسّط/الرتبة.

مثال (21.6-15): التطبيقات المعطيات: تعلّم معزّز آمن. المطلوب: الاستخدام. الحل: الخطوة 1: نُسقط السياسة على مجموعة آمنة بعد كلّ تحديث. النتيجة: ضمانات سلامة. الربط بالذكاء الاصطناعي: RL safe والقيود الصارمة.

أخطاء شائعة

- إسقاط على مجموعة غير محدّبة (الفرادة تفقد).
- نسيان أنّ الإسقاط قد يكون مكلفاً حسابيّاً.
- استخدام خطوة كبيرة قبل الإسقاط فيفقد التقدّم.
- الخلط بين الإسقاط والقصّ البسيط في غير الصندوق.

عقوبة تربيعية ولاغرانج معزّز (بمعلمة $\rho > 0$):

$$\min_x f(x) + \frac{\rho}{2}\sum_j h_j(x)^2, \qquad \mathcal{L}_\rho(x,\lambda) = f(x) + \lambda^\top h(x) + \frac{\rho}{2}\|h(x)\|^2 \tag{21.6}$$

وتحديث المضاعف: $\lambda \leftarrow \lambda + \rho\, h(x)$.

جدول الرموز

الرمز	المعنى
ρ	معلمة العقوبة
$\mathcal{L}_\rho$	اللاغرانجي المعزّز
تحديث λ	صعود ثنائي بخطوة ρ

الرسم

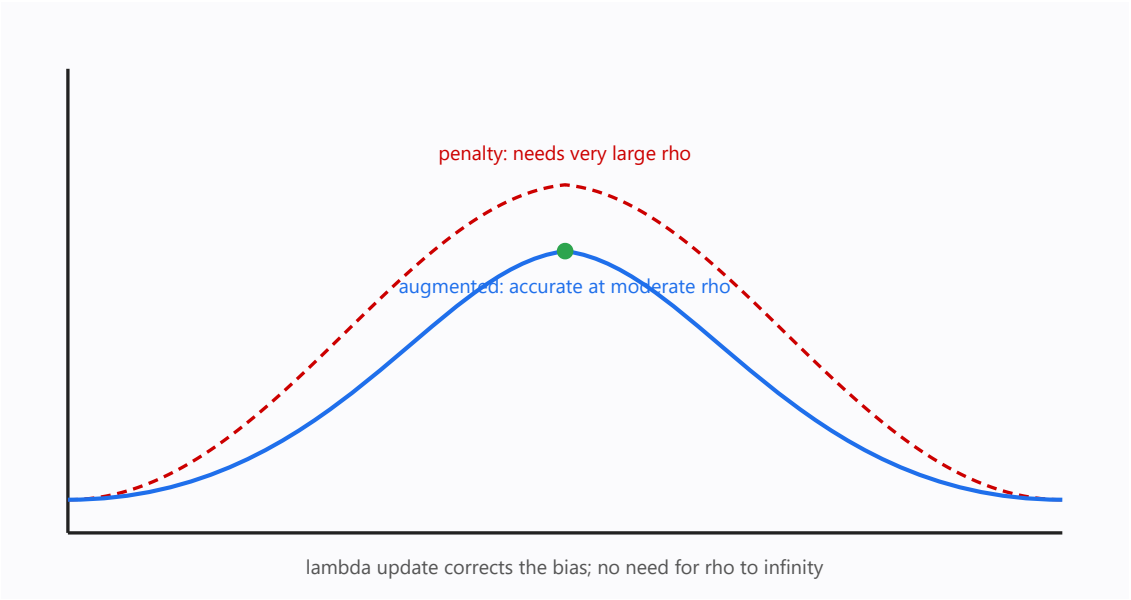
<figure> الشكل<figcaption> 21.6: العقوبة تحتاج $\rho \to \infty$ (سوء تكييف)؛ المعزّز يحقّق الدقّة بـ ρ معتدل.</figcaption> </figure>

البرهان (مخطّط)

العقوبة التربيعية تعاقب المخالفة بـ $\frac{\rho}{2}\|h\|^2$، فالحلّ يقترب من الممكن كلما كبر ρ لكن رقم الحالة يتدهور. اللاغرانجي المعزّز يضيف $\lambda^\top h$ فيصحّح الانحياز، فلا نحتاج $\rho \to \infty$؛ تحديث λ هو صعود ثنائي على $\mathcal{L}_\rho$. ■

خمسة عشر مثالاً محلولاً

مثال (21.7-1): طريقة العقوبة المعطيات: $\min x^2$ بشرط $x = 1$. المطلوب: المسألة المعاقَبة. الحل: الخطوة 1: $\min x^2 + \frac{\rho}{2}(x-1)^2$. الخطوة 2: الحلّ $x = \frac{\rho}{2+\rho} \to 1$ كلما $\rho \to \infty$. النتيجة: تقارب إلى الممكن. الربط بالذكاء الاصطناعي: قيود ناعمة في التدريب.



شكل ٦.٢١: *
طريقة العقوبة ولاغرانج المعزز

مثال (2-7.21): الحاجة لـ ρ كبير المعطيات: $\rho = 1$. المطلوب: الدقّة. الحل: الخطوة 1: $x = 1/3$ بعيد عن 1. النتيجة: نرفع ρ. الربط بالذكاء الاصطناعي: معايرة قوة العقوبة.

مثال (3-7.21): سوء التكييف المعطيات: $\rho = 10^6$. المطلوب: الأثر. الحل: الخطوة 1: الهِسّية تصير $\rho \approx \Rightarrow$ رقم حالة ضخم (من 5.20). النتيجة: بطء/عدم استقرار عددي. الربط بالذكاء الاصطناعي: لماذا نفضّل المعزّز.

مثال (4-7.21): تعريف المعزّز المعطيات: نفس المسألة. المطلوب: $\mathcal{L}_\rho$. الحل: الخطوة 1: $x^2+\lambda(x-1)+\frac{\rho}{2}(x-1)^2$. النتيجة: اللاغرانجي المعزّز. الربط بالذكاء الاصطناعي: أساس ADMM.

مثال (5-7.21): تحديث المضاعف المعطيات: x الحالي يخالف بـ $h = 0.2$، $\rho = 5$. المطلوب: التحديث. الحل: الخطوة 1: $\lambda \leftarrow \lambda + 5(0.2) = \lambda + 1$. النتيجة: تصحيح تدريجي. الربط بالذكاء الاصطناعي: تكيّف ذاتي للقيود.

مثال (6-7.21): المعزّز لا يحتاج $\rho \to \infty$ المعطيات: مع λ صحيح. المطلوب: الدقّة. الحل: الخطوة 1: الحلّ الدقيق بـ ρ معتدل. النتيجة: دقّة دون سوء تكييف. الربط بالذكاء الاصطناعي: متانة عددية.

مثال (7-7.21): تقسيم ADMM المعطيات: $\min f(x)+g(z)$ بشرط $Ax+Bz=c$. المطلوب: الفكرة. الحل: الخطوة 1: نحدّث x ثمّ z ثمّ λ بالتناوب. النتيجة: تفكيك المسألة. الربط بالذكاء الاصطناعي: تحسين قابل للتوسعة.

مثال (8-7.21): تحديثات ADMM المعطيات: الخطوات الثلاث. المطلوب: الترتيب. الحل: الخطوة 1: x (يصغّر $\mathcal{L}_\rho$)، z (يصغّر)، λ (يصعد). النتيجة: تكرار منسّق. الربط بالذكاء الاصطناعي: تنفيذ ADMM.

مثال (9-7.21): ADMM للاسو المعطيات: $\min \frac{1}{2}\|Xw-y\|^2+\lambda\|z\|_1$ بشرط $w=z$. المطلوب: التطبيق. الحل: الخطوة 1: تحديث w تربيعي، z قصّ ناعم. النتيجة: حلّ فعال للاسو. الربط بالذكاء الاصطناعي: تناثر واسع النطاق.

مثال (10-7.21): ADMM للتوافق المعطيات: عدّة عُقد بحلول محلّية. المطلوب: الدمج. الحل: الخطوة 1: قيد توافق يوحّد الحلول. النتيجة: تعلّم موزّع. الربط بالذكاء الاصطناعي: federated learning.

مثال (11-7.21): عقوبة ناعمة للمخالفة المعطيات: نسمح بمخالفة صغيرة. المطلوب: التفسير. الحل: الخطوة 1: ρ متوسط $\Rightarrow$ مخالفة مقبولة. النتيجة: قيد «ناعم». الربط بالذكاء الاصطناعي: مفاضلة الدقّة مقابل القيد.

مثال (12-7.21): الحاجز اللوغاريتمي المعطيات: قيد $x \geq 0$. المطلوب: البديل. الحل: الخطوة 1: نضيف $-\frac{1}{t}\sum \log x_i$ (حاجز). النتيجة: يمنع المخالفة من الداخل. الربط بالذكاء الاصطناعي: interior-point methods.

مثال (7.21-13): جدولة t المعطيات: نزيد t تدريجيّاً. المطلوب: الهدف. الحل: الخطوة 1: نقترب من الحلّ دون سوء تكييف مبكر. النتيجة: مسار مركزي. الربط بالذكاء الاصطناعي: محلّلات QP/IPM.

مثال (7.21-14): عقوبة مقابل إسقاط المعطيات: نقارن الطريقتين. المطلوب: المقايضة. الحل: الخطوة 1: الإسقاط دقيق وتكلفته إسقاط؛ العقوبة رخيصة وتقريبية. النتيجة: دليل الاختيار. الربط بالذكاء الاصطناعي: تصميم المدرّب.

مثال (7.21-15): تدريب مقيّد عمليّاً المعطيات: شبكة بقيود على المخرجات. المطلوب: التنفيذ. الحل: الخطوة 1: نضيف عقوبة على المخالفة للخسارة. النتيجة: تدريب عملي. الربط بالذكاء الاصطناعي: قيود العمل/الإنصاف في النماذج.

أخطاء شائعة

- رفع ρ بلا حدود فيسبب عدم استقرار.
- نسيان تحديث λ في المعزّز (فيصير مجرّد عقوبة).
- استخدام عقوبة عندما نحتاج دقّة صارمة.
- الخلط بين معلمة العقوبة ومعلمة الحاجز.

SVM بهامش صلب (قابل للفصل خطّياً):

$$\min_{w,b} \ \frac{1}{2}\|w\|^2 \quad \text{s.t.} \quad y_i\big(w^\top x_i + b\big) \geq 1, \quad y_i \in \{\pm 1\} \tag{7.21}$$

والهامش الهندسي $1/\|w\|$؛ والنسخة الناعمة بإدخال تراخٍ $\xi_i \geq 0$ وعقوبة $C\sum \xi_i$.

جدول الرموز

الرمز	المعنى
w, b	المستوي الفائق
$1/\|w\|$	الهامش
ξ_i	تراخي المخالفة
C	مفاضلة الهامش/الخطأ
α_i	مضاعفات الثنائية

الرسم

<figure> الشكل 7.21: نعظّم الهامش بين الفئتين؛ النقاط على الحدود هي أشعة الدعم ($\alpha_i > 0$).</figcaption> </figure>

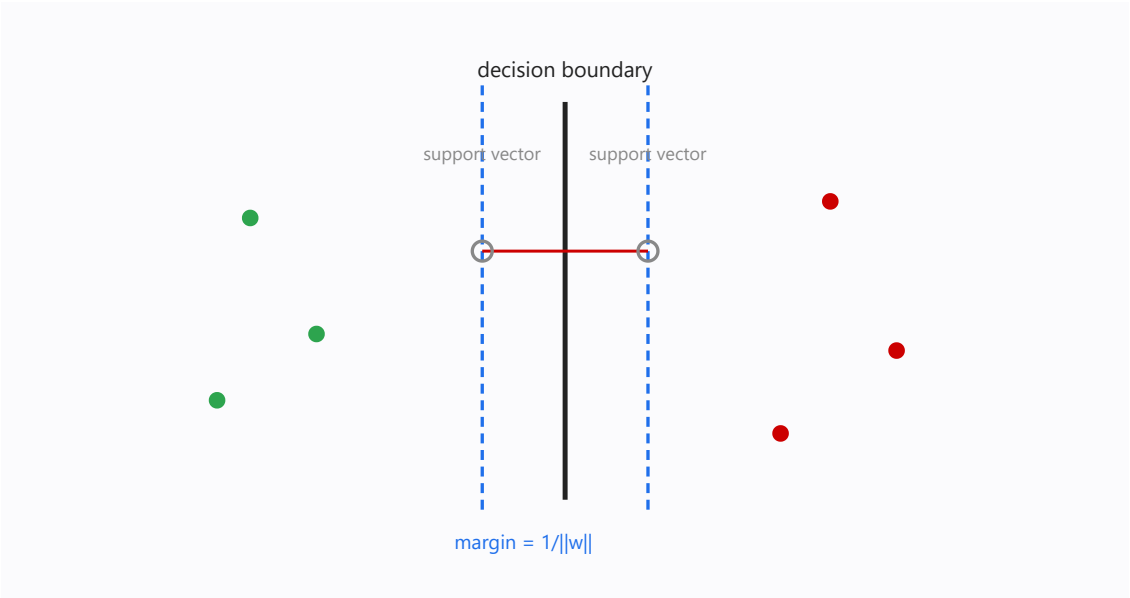
البرهان (مخطّط)

الهامش للمستوي $w^\top x + b = 0$ هو $\min_i |y_i(w^\top x_i + b)|/\|w\|$؛ بتحجيم w, b نفرض $y_i(w^\top x_i + b) \geq 1$ فتصير المسافة $1/\|w\|$، وتعظيمها يكافئ تقليل $\frac{1}{2}\|w\|^2$ $\Rightarrow$ (7.21). ■

خمسة عشر مثالاً محلولاً

مثال (8.21-1): صيغة الهامش الصلب المعطيات: بيانات قابلة للفصل. المطلوب: الهدف. الحل: الخطوة 1: $\min \frac{1}{2}\|w\|^2$ بشرط الهامش ≥ 1. النتيجة: (7.21). الربط بالذكاء الاصطناعي: SVM الكلاسيكي.

مثال (8.21-2): الهامش $1/\|w\| = 2 = \|w\|$ المعطيات: المطلوب: الهامش. الحل: الخطوة 1: $1/2$. النتيجة: هامش 5.0. الربط بالذكاء الاصطناعي: قياس فصل الفئات.



شكل ٧.٢١: *
SVM: الهامش وقيود التصنيف

مثال (3-8.21): الهامش الناعم المعطيات: بيانات غير قابلة للفصل. المطلوب: التعديل. الحل: الخطوة 1: نضيف $\xi_i \geq 0$ وشرط $y_i(w^\top x_i + b) \geq 1 - \xi_i$. الخطوة 2: الهدف $\frac{1}{2}\|w\|^2 + C\sum \xi_i$. النتيجة: SVM ناعم. الربط بالذكاء الاصطناعي: التعامل مع الضوضاء.

مثال (4-8.21): خسارة المفصلة المعطيات: النسخة غير المقيّدة. المطلوب: الصيغة. الحل: الخطوة 1: $\frac{1}{2}\|w\|^2 + C\sum \max(0, 1 - y_i(w^\top x_i + b))$. النتيجة: hinge loss. الربط بالذكاء الاصطناعي: تدريب SVM بـ SGD.

مثال (5-8.21): الثنائية والأساس النووي المعطيات: الثنائية من 6-4.21. المطلوب: النواة. الحل: الخطوة 1: $x_i^\top x_j$ تُستبدل بـ $K(x_i, x_j)$. النتيجة: SVM نَوَوي غير خطّي. الربط بالذكاء الاصطناعي: RBF/Gaussian kernels.

مثال (6-8.21): أشعة الدعم المعطيات: $\alpha_i > 0$. المطلوب: المعنى. الحل: الخطوة 1: تلك النقاط على الهامش (الركود المكمّل). النتيجة: الحلّ يعتمد على قلّة فقط. الربط بالذكاء الاصطناعي: تناثر الحلّ وكفاءة التنبّؤ.

مثال (7-8.21): الصيغة التربيعية العامّة المعطيات: $\min \frac{1}{2}x^\top Qx + c^\top x$ بشرط $Ax \leq b$. المطلوب: التصنيف. الحل: الخطوة 1: برمجة تربيعية (QP)؛ محدّبة إن $Q \succcurlyeq 0$. النتيجة: إطار يحوي SVM/المحفظة. الربط بالذكاء الاصطناعي: محلّلات QP في المكتبات.

مثال (8-8.21): QP بقيود مساواة المعطيات: $Q \succ 0$، $Ax = b$. المطلوب: الحلّ. الحل: الخطوة 1: نظام KKT خطّي 2×2 بالكامل. النتيجة: حلّ مغلق. الربط بالذكاء الاصطناعي: حلول سريعة للنماذج الصغيرة.

مثال (9-8.21): محفظة كـ QP المعطيات: $\min w^\top \Sigma w$ بشرط $\sum w = 1$، $w \geq 0$، عائد $\geq r$. المطلوب: التصنيف. الحل: الخطوة 1: QP محدّب. النتيجة: تخصيص مثالي. الربط بالذكاء الاصطناعي: إدارة المخاطر/الموارد.

مثال (10-8.21): انحدار SVM (SVR) المعطيات: نريد أنبوبة ϵ. المطلوب: الصيغة. الحل: الخطوة 1: نسمح بأخطاء داخل ϵ ونعاقب خارجها. النتيجة: SVR. الربط بالذكاء الاصطناعي: تنبّؤ متين.

مثال (11-8.21): MLE مقيّد المعطيات: معاملات يجب أن تبقى في مجال. المطلوب: المعالجة. الحل: الخطوة 1: إسقاط أو عقوبة أو إعادة توسيط. النتيجة: تقدير مشروع. الربط بالذكاء الاصطناعي: قيود معاملات النموذج.

مثال (12-8.21): تعلّم معزّز آمن المعطيات: قيد على التكلفة التراكمية. المطلوب: الصياغة. الحل: الخطوة 1: max

العائد بشرط تكلفة $\leq$ حدّ $\Rightarrow$ لاغرانجي. النتيجة: سياسة آمنة. الربط بالذكاء الاصطناعي: MDP. Constrained

مثال (21.8-13): قيود الإنصاف المعطيات: معدّلات متساوية عبر المجموعات. المطلوب: الصياغة. الحل: الخطوة 1: قيود على الفروق الإحصائية $\Rightarrow$ مسألة مقيّدة. النتيجة: نموذج عادل قدر الإمكان. الربط بالذكاء الاصطناعي: ML. fairness-aware

مثال (21.8-14): تخصيص الموارد المعطيات: ميزانية ثابتة ومكاسب متناقصة. المطلوب: النموذج. الحل: الخطوة 1: تعظيم مقعّر بقيود خطّية $\Rightarrow$ محدّب. النتيجة: تخصيص أمثل. الربط بالذكاء الاصطناعي: جدولة/حوسبة سحابية.

مثال (21.8-15): اختيار C المعطيات: C كبير مقابل صغير. المطلوب: الأثر. الحل: الخطوة 1: C كبير $\Rightarrow$ هامش ضيّق وخطأ تدريب أقل (إفراط محتمل). النتيجة: ضبط بالمصادقة. الربط بالذكاء الاصطناعي: ضبط هايبرمعاملات (الفصل 30).

أخطاء شائعة

- نسيان تحجيم w, b عند حساب الهامش.
- استخدام SVM صلب على بيانات غير قابلة للفصل.
- الخلط بين C ومعلمة النواة.
- تجاهل أنّ الثنائية هي ما يسمح بالنواة لا الأولى.

ملخّص النظريات

النظرية	المفهوم	التطبيق
21.2 لاغرانج	$\nabla f + \sum \lambda_j \nabla h_j = 0$	قيود المساواة
21.3 KKT	$\mu_i g_i = 0$، $\mu \geq 0$	قيود اللامساواة
21.4 الثنائية	$g = \inf_x \mathcal{L}$ مقعّرة	إطار محدّب
21.5 ضعيفة/قوية	$d^\star \leq p^\star$، سلاتر $\Rightarrow$ مساواة	شهادة الأمثلية
21.6 الإسقاط	$x_+ = \Pi_C(x - \eta \nabla f)$	قيود صندوق/مبسّط
21.7 العقوبة/المعزّز	$\mathcal{L}_\rho$، تحديث λ	ADMM
21.8 التطبيقات	QP SVM،	تصنيف/تخصيص

عشرون تمريناً (مع إجابات مختصرة)

١. اكتب شرط لاغرانج لقيود المساواة. $(\nabla f + \sum \lambda_j \nabla h_j = 0)$

٢. ما إشارة λ في المساواة؟ (حرّة)

٣. اذكر شروط KKT الأربعة. (الاستقرارية، الممكنية، $\mu \geq 0$، الركود)

٤. متى يكون القيد نشطاً؟ $(g_i = 0)$

٥. ماذا يعني $\mu_i g_i = 0$؟ (الركود المكمّل)

٦. عرّف الدالّة الثنائية. $(g = \inf_x \mathcal{L})$

٧. لماذا g مقعّرة؟ (inf لتآلفية)

٨. اكتب الثنائية الضعيفة. $(d^\star \leq p^\star)$

٩. ما شرط سلاتر؟ (نقطة ممكنة داخلية صارمة)

١٠. متى نحصل على ثنائية قوية؟ (محدّب + سلاتر)

١١. عرّف الإسقاط. ($\arg\min_{x\in C}\|x-z\|^2$)

١٢. إسقاط على صندوق $[0,1]$. ($\min(1,\max(0,z))$)

١٣. إسقاط على كرة L2 بـ r. ($rz/\|z\|$ إن تجاوز)

١٤. اكتب اللاغرانجي المعزّز. ($f+\lambda^\top h+\frac{\rho}{2}\|h\|^2$)

١٥. تحديث المضاعف في المعزّز. ($\lambda\leftarrow\lambda+\rho h$)

١٦. عيب العقوبة التربيعية؟ (سوء التكييف عند ρ كبير)

١٧. اكتب هدف SVM الصلب. ($\min\frac{1}{2}\|w\|^2$ بشرط الهامش)

١٨. ما الهامش؟ ($1/\|w\|$)

١٩. ما أشعة الدعم؟ (النقاط بـ $\alpha_i>0$)

٢٠. لماذا تظهر النواة في الثنائية؟ (لأنّها تعتمد على $x_i^\top x_j$ فقط)

فهرس الرموز

الرمز	المعنى
h_j, g_i	قيود المساواة واللامساواة
λ_j, μ_i	المضاعفات
$\mathcal{L}, \mathcal{L}_\rho$	اللاغرانجي والمعزّز
$p^\star, d^\star$	القيمتان المثليتان
Π_C	الإسقاط
w, b, ξ, α	رموز SVM

مراجع

- Vandenberghe & Boyd — *Optimization Convex* (الفصل 5: الثنائية).
- Wright & Nocedal — *Optimization Numerical* (الفصول 12 و17).
- Bertsekas — *Methods Multiplier Lagrange and Optimization Constrained*.
- Boyd et al. — «Distributed Optimization and Statistical Learning via ADMM».
- Smola & Schölkopf — *Learning with Kernels*.

خاتمة: القيود تحوّل التحسين من «إيجاد قاع» إلى «إيجاد قاع داخل جدار». الفصل 22 ينقلنا إلى **المحسّنات العشوائية** (SGD وبدائله)، حيث لا نرى التدرّج كاملاً بل نراه بالعيّنات.

التحسين المحدّب ونظرية الازدواج

«التحدّب هو الخطّ الفاصل بين ما نستطيع حلّه وما لا نستطيع.»

في الفصل العشرين رأينا أنّ التحدّب يجعل كلّ نقطة حرجة عالمية، وفي الحادي والعشرين بنينا الثنائية اللاغرانجية. هذا الفصل يؤسّس **التحليل المحدّب** نفسه: المجموعات المحدّبة ونظرية الفصل، الدوالّ المحدّبة وعملياتها، التدرّج الجزئي للدوالّ غير السلسة، ثمّ **الازدواج المترافق** (Fenchel) الذي يعيد صياغة الثنائية بصورة أنصع، وأخيراً **المؤثّر القريب** الذي يجعل كلّ ذلك خوارزمية.
سبع نظريات:

- **2.22 المجموعات المحدّبة ونظرية الفصل** — المستوي الفائق الفاصل.
- **3.22 الدوالّ المحدّبة وعملياتها** — ما يحفظ التحدّب.
- **4.22 التدرّج الجزئي** — للدوالّ غير السلسة كـ L1.
- **5.22 الازدواج المترافق (Fenchel)** — $f^\star$.
- **6.22 ازدواج فنشل-روكافلر** — الثنائية المترافقة العامّة.
- **7.22 المؤثّر القريب والنزول القريب** — ISTA.
- **8.22 التسريع FISTA** — المعدّل $O(1/k^2)$.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى
C	مجموعة محدّبة
$\operatorname{conv}(S)$	الغلاف المحدّب
∂f	التدرّج الجزئي (subgradient)
$f^\star$	المترافق (conjugate)
$\operatorname{prox}_{\gamma f}$	المؤثّر القريب
I_C	دالّة المؤشّر

المجموعة محدّبة إذا كان لكلّ $x, y \in C$ و $t \in [0,1]$: $tx + (1-t)y \in C$.

نظرية الفصل القوي:

إذا كانت C مغلقة محدّبة و $z \notin C$، فوُجد مستوٍ فائق يفصل بينهما بشكل صارم:

$$a^\top z \;>\; \alpha \;\geq\; a^\top x \quad \forall x \in C \tag{1.22}$$

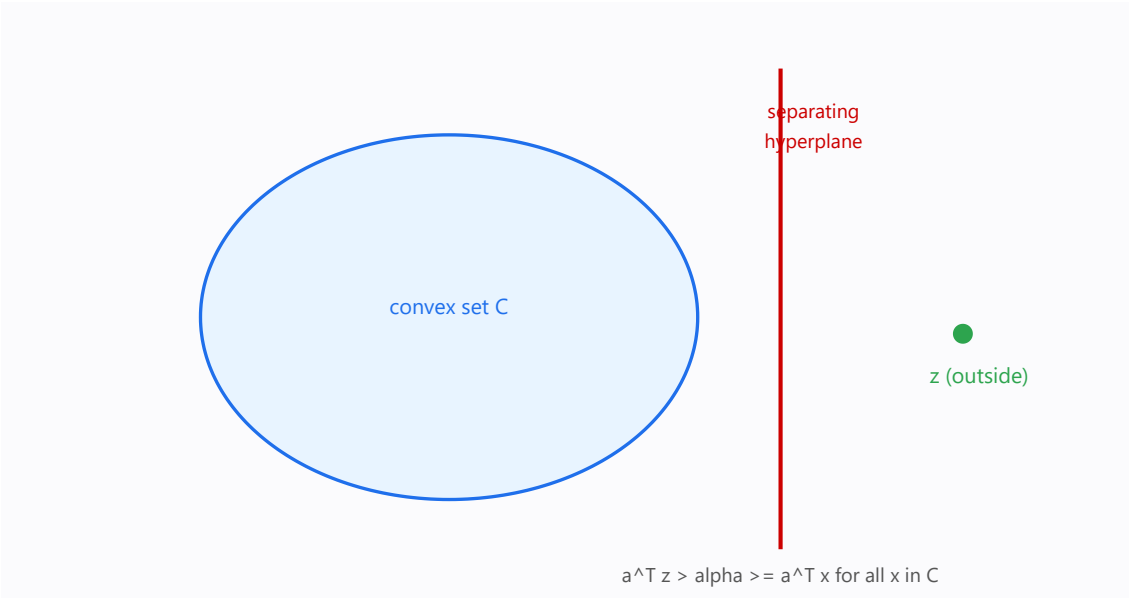
والمستوي الفائق الداعم يماسّ C على حدودها.

جدول الرموز

الرمز	المعنى
a	عمودي المستوي الفائق
α	الإزاحة
فصل صارم	$a^\top z > \alpha \geq \sup_C a^\top x$
داعم	يماسّ ولا يقطع الداخل

الرسم

<figure> الشكل<figcaption> 1.22: مستوٍ فائق يفصل نقطة خارج مجموعة محدّبة مغلقة.</figcaption> </figure>



شكل ١.٢٢: *
المجموعات المحدبة ونظرية الفصل

البرهان (مخطّط)

ليكن $x_0 = \Pi_C(z)$ الإسقاط (من 6.21). نضع $a = z - x_0 \neq 0$ و $\alpha = a^\top x_0$. بالمبرهنة الإسقاطية $(z - x_0)^\top (x - x_0) \leq 0$ لكلّ $x \in C$، أي $a^\top x \leq a^\top x_0 = \alpha$. و $a^\top z - \alpha = \|a\|^2 > 0 \Rightarrow (1.22)$. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.22): اختبار مجموعة محدّبة المعطيات: قرص وحدة $\{x : \|x\| \leq 1\}$. المطلوب: هل محدّبة؟ الحل: الخطوة 1: لكلّ x, y في القرص، $\|\lambda x + (1-\lambda)y\| \leq \lambda\|x\| + (1-\lambda)\|y\| \leq 1$ بالمتراجحة المثلثية (من 5). النتيجة: محدّبة. الربط بالذكاء الاصطناعي: قيود نُرم الأوزان مجموعة محدّبة.

مثال (2-2.22): مجموعة غير محدّبة المعطيات: اتحاد نقطتين منفصلتين. المطلوب: التحدّب؟ الحل: الخطوة 1: القطعة بينهما ليست في المجموعة. النتيجة: غير محدّبة. الربط بالذكاء الاصطناعي: فضاءات متقطّعة (مثل الأوزان الثنائية).

مثال (3-2.22): الغلاف المحدّب المعطيات: نقاط متفرّقة. المطلوب: التعريف. الحل: الخطوة 1: أصغر مجموعة محدّبة تحويها = جميع المتوسطات المرجّحة. النتيجة: $\mathrm{conv}(S)$. الربط بالذكاء الاصطناعي: تمثيلات مختلطة/distributions.

مثال (4-2.22): تقاطع المحدّبات المعطيات: C_1, C_2 محدّبتان. المطلوب: التقاطع. الحل: الخطوة 1: القطعة بين

نقطتين في التقاطع تبقى في كلتيهما. النتيجة: محدّبة. الربط بالذكاء الاصطناعي: تقاطع قيود متعدّدة يبقى محدّباً.

مثال (2.22-5): نصف فضاء المعطيات: $\{x : a^\top x \le b\}$. المطلوب: النوع. الحل: الخطوة 1: محدّبة (تركيبة خطّية تحفظ اللامساواة). النتيجة: لبنة أساسية. الربط بالذكاء الاصطناعي: قيود خطّية في SVM/QP.

مثال (2.22-6): مخروط موجب نصف التحديد المعطيات: $\{X \succeq 0\}$. المطلوب: التحدّب. الحل: الخطوة 1: $\lambda X + (1-\lambda)Y \succeq 0$ من تعريف PSD (من 5.15). النتيجة: مخروط محدّب. الربط بالذكاء الاصطناعي: قيود مصفوفات التغاير/النواة.

مثال (2.22-7): بناء المستوي الفاصل المعطيات: $z = (2,0)$، C قرص وحدة. المطلوب: الفاصل. الحل: الخطوة 1: $x_0 = (1,0)$، $a = (1,0)$، $\alpha = 1$. الخطوة 2: $a^\top z = 2 > 1 \ge a^\top x$. النتيجة: الفاصل $x_1 = 1$. الربط بالذكاء الاصطناعي: شهادة أنّ نقطة خارج المنطقة المسموحة.

مثال (2.22-8): فصل مجموعتين المعطيات: مجموعتان محدّبتان منفصلتان. المطلوب: النتيجة. الحل: الخطوة 1: يوجد فاصل (بتطبيق النظرية على الفرق $C_1 - C_2$). النتيجة: قابلية الفصل الخطّي. الربط بالذكاء الاصطناعي: أساس نظري لـ SVM الخطّي.

مثال (2.22-9): SVM والفصل المعطيات: فئتان بأغلفة محدّبة منفصلة. المطلوب: المعنى. الحل: الخطوة 1: المستوي الفاصل بأكبر هامش هو SVM (من 8.21). النتيجة: الفصل + تعظيم الهامش. الربط بالذكاء الاصطناعي: SVM من نظرية الفصل.

مثال (2.22-10): المستوي الداعم المعطيات: نقطة حدودية x_b. المطلوب: الخاصّية. الحل: الخطوة 1: يوجد $a \neq 0$ بـ $a^\top x \le a^\top x_b$ لكلّ $x \in C$. النتيجة: داعم عند الحدود. الربط بالذكاء الاصطناعي: تحليل نقاط الحدود/القيود النشطة.

مثال (2.22-11): فصل ضعيف المعطيات: مجموعتان تتماسّان. المطلوب: النوع. الحل: الخطوة 1: فصل غير صارم ($a^\top x \le \alpha \le a^\top y$). النتيجة: فصل ضعيف فقط. الربط بالذكاء الاصطناعي: حالات التماسّ الحدّية.

مثال (2.22-12): مبرهنة فِركا (Farkas) المعطيات: نظام $Ax = b$، $x \ge 0$. المطلوب: شرط الحلّ. الحل: الخطوة 1: إمّا يوجد $x \ge 0$ بـ $Ax = b$، أو يوجد y بـ $A^\top y \ge 0$ و $b^\top y < 0$. النتيجة: بديلان حصريّان. الربط بالذكاء الاصطناعي: جدوى القيود/التحقّق.

مثال (2.22-13): إسقاط وفصل معاً المعطيات: الإسقاط يبني الفاصل. المطلوب: العلاقة. الحل: الخطوة 1: $a = z - \Pi_C(z)$ هو العمودي الفاصل. النتيجة: ربط 6.21 بـ 2.22. الربط بالذكاء الاصطناعي: خوارزميات إيجاد الفواصل.

مثال (2.22-14): محدّبية فضاء الاحتمالات المعطيات: المبسّط $\{p : \sum p_i = 1, p_i \ge 0\}$. المطلوب: النوع. الحل: الخطوة 1: تقاطع نصف فضاءات ومستوٍ $\Rightarrow$ محدّب ومغلق. النتيجة: فضاء محدّب مدمج. الربط بالذكاء الاصطناعي: توزيعات softmax تعيش على المبسّط.

مثال (2.22-15): لماذا يهمّ الفصل المعطيات: مسألة غير محدّبة. المطلوب: الاسترخاء. الحل: الخطوة 1: نسترخي للغلاف المحدّب فنستفيد من نظرية الفصل. النتيجة: حدود واسترخاءات قابلة للحلّ. الربط بالذكاء الاصطناعي: استرخاءات محدّبة في التحسين المتقطّع.

أخطاء شائعة

- افتراض فصل صارم لمجموعتين متماسّتين.
- نسيان شرط الانغلاق والمحدّدية للفصل القوي.
- الخلط بين الغلاف المحدّب والمجموعة نفسها.

- استخدام نظرية الفصل على مجموعات غير محدّبة.

f محدّبة على مجموعة محدّبة C إذا:

$$f\big(tx + (1-t)y\big) \;\le\; tf(x) + (1-t)f(y), \quad \forall x, y \in C,\ t \in [0,1] \tag{2.22}$$

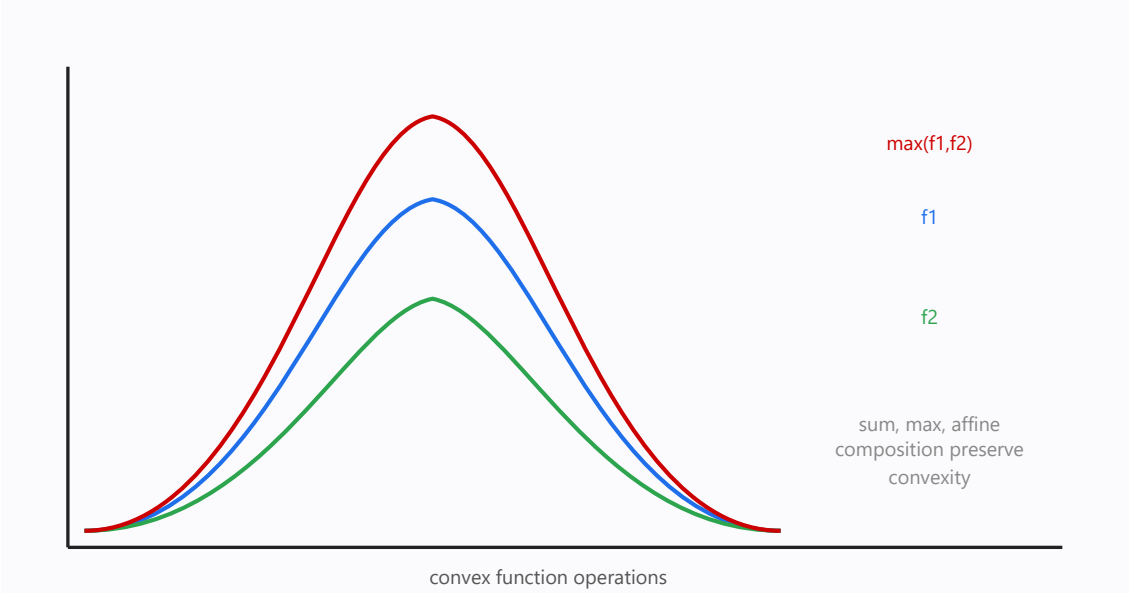
والعمليات الحافظة: الجمع المرجّح غير السالب، الأعظمي، التركيب مع التآلفي، و $(x,t) \mapsto tf(x/t)$ (المنظور).

جدول الرموز

الرمز	المعنى
t	وزن المزج في $[0,1]$
$\max_i f_i$	الأعظمي يحفظ التحدّب
منظور	$tf(x/t)$
$\mathrm{epi} f$	الرسم الفوقي (epigraph)

الرسم

<figure> الشكل<figcaption> 2.22: الجمع، الأعظمي، والتركيب التآلفي تحفظ التحدّب.</figcaption>



شكل ٢٠٢٢: *
الدوال المحدبة والعمليات الحافظة للتحدب

</figure>

البرهان (مخطّط)

الجمع المرجّح: بمتراجحة التحدّب لكلّ حدّ ثمّ الجمع. الأعظمي: $\mathrm{epi}\max_i f_i = \cap_i \mathrm{epi} f_i$ وتقاطع المحدّبات محدّب (من 2.22). المنظور: من محدّبية الرسم الفوقي المخروطي. ■

خمسة عشر مثالاً محلولاً

مثال (22.3-1): اختبار بالتعريف المعطيات: $f(x) = x^2$. المطلوب: البرهان. الحل: الخطوة 1: $(tx + (1-t)y)^2 \le tx^2 + (1-t)y^2$ (يكافئ $t(1-t)(x-y)^2 \ge 0$). النتيجة: محدّبة. الربط بالذكاء الاصطناعي: خسارة MSE.

مثال (22.3-2): الرسم الفوقي المعطيات: $\text{epi} f = \{(x,t) : t \ge f(x)\}$. المطلوب: العلاقة. الحل: الخطوة 1: f محدّبة iff $\text{epi} f$ مجموعة محدّبة. النتيجة: تكافؤ هندسي. الربط بالذكاء الاصطناعي: صياغة المسائل بصورة هندسية.

مثال (22.3-3): جمع مرجّح المعطيات: f_1, f_2 محدّبتان، $\alpha_1, \alpha_2 \ge 0$. المطلوب: النتيجة. الحل: الخطوة 1: بمتراجحة كلّ منهما ثمّ الجمع المرجّح. النتيجة: محدّبة. الربط بالذكاء الاصطناعي: خسارة + تنظيم محدّب.

مثال (22.3-4): الأعظمي المعطيات: $f = \max(f_1, f_2)$. المطلوب: النوع. الحل: الخطوة 1: تقاطع الرسوم الفوقية $\Rightarrow$ محدّبة. النتيجة: محدّبة (قد تكون غير سلسة). الربط بالذكاء الاصطناعي: loss hinge من أعظمي.

مثال (22.3-5): hinge غير سلسة المعطيات: $\max(0, 1 - yf(x))$. المطلوب: النوع. الحل: الخطوة 1: أعظمي تآلفيتين $\Rightarrow$ محدّبة غير سلسة. النتيجة: تحتاج تدرّجاً جزئياً (4.22). الربط بالذكاء الاصطناعي: SVM بتدرّج جزئي.

مثال (22.3-6): التركيب التآلفي المعطيات: $f(x) = \|Ax - b\|^2$. المطلوب: التحدّب. الحل: الخطوة 1: النُرم محدّب ومركّب مع تآلفي $\Rightarrow$ محدّب. النتيجة: محدّبة دائماً. الربط بالذكاء الاصطناعي: الانحدار الخطّي/الشبكة بآخر خطّي.

مثال (22.3-7): المنظور المعطيات: $g(x,t) = tf(x/t)$ بـ $t > 0$. المطلوب: الاستخدام. الحل: الخطوة 1: يحفظ التحدّب، يفيد في تحويلات القياس. النتيجة: أداة بناء. الربط بالذكاء الاصطناعي: نسب ومقاييس في الأهداف.

مثال (22.3-8): الإنتروبيا السالبة المعطيات: $f(p) = \sum p_i \log p_i$. المطلوب: النوع. الحل: الخطوة 1: الهِسّية $\text{diag}(1/p_i) \succ 0$ $\Rightarrow$ محدّبة صارمة. النتيجة: محدّبة. الربط بالذكاء الاصطناعي: خسارة الإنتروبيا المتقاطعة (الفصل 26).

مثال (22.3-9): اللوجستي المعطيات: $\log(1 + e^{-z})$. المطلوب: النوع. الحل: الخطوة 1: محدّبة في z، ومركّبة مع $z = w^\top x$ $\Rightarrow$ محدّبة في w. النتيجة: محدّبة. الربط بالذكاء الاصطناعي: تدريب لوجستي مضمون.

مثال (22.3-10): النُرم المعطيات: أيّ نُرم $\|x\|$. المطلوب: التحدّب. الحل: الخطوة 1: بالمتراجحة المثلثية والتجانس (من الفصل 5). النتيجة: محدّب. الربط بالذكاء الاصطناعي: تنظيمات L1/L2.

مثال (22.3-11): دوالّ النقطة القصوى المعطيات: $f(x) = \max_i (a_i^\top x + b_i)$. المطلوب: النوع. الحل: الخطوة 1: أعظمي تآلفيات $\Rightarrow$ محدّبة متعدّدة السطوح. النتيجة: piecewise-linear محدّبة. الربط بالذكاء الاصطناعي: ReLU كأعظمي (محدّبة).

مثال (22.3-12): الشبكة غير المحدّبة المعطيات: خسارة شبكة عميقة. المطلوب: التحدّب؟ الحل: الخطوة 1: تركيب غير خطّي لا يحفظ التحدّب $\Rightarrow$ غير محدّبة. النتيجة: تحسين غير محدّب. الربط بالذكاء الاصطناعي: يبرّر طرق الرتبة الأولى.

مثال (22.3-13): محدّب لكن ليس سلساً المعطيات: $|x|$ و $\max(0, x)$. المطلوب: الملاحظة. الحل: الخطوة 1: محدّبة غير قابلة للاشتقاق في نقاط. النتيجة: نحتاج تدرّجاً جزئياً. الربط بالذكاء الاصطناعي: L1/ReLU في الممارسة.

مثال (22.3-14): التحدّب المقيّد المعطيات: g محدّبة، f محدّبة غير متناقصة. المطلوب: $f \circ g$. الحل: الخطوة 1: محدّبة بقاعدة التركيب. النتيجة: شرط «غير متناقصة» ضروري. الربط بالذكاء الاصطناعي: تصميم خسائر مركّبة.

مثال (22.3-15): محدّبية في التعلّم المعطيات: لماذا نهتمّ؟ المطلوب: الفائدة. الحل: الخطوة 1: محلّي = عالمي، ولا سروج مضلّلة. النتيجة: ضمانات تقارب قويّة. الربط بالذكاء الاصطناعي: متى نثق بالتدريب؟

أخطاء شائعة

- افتراض أنّ التركيب يحفظ التحدّب دائماً (يحتاج شروطاً).
- نسيان أنّ الأعظمي قد يكسر السلاسة.
- الخلط بين المحدّب والمقعّر في إشارة الخسارة.
- تجاهل المجال (التحدّب على مجال محدّب فقط).

لدالّة محدّبة f (قد تكون غير سلسة)، المتّجه g تدرّج جزئي عند x إذا:

$$f(y) \;\geq\; f(x) + g^{\top}(y - x) \quad \forall y, \qquad \partial f(x) = \{g : \text{يحقّق ذلك}\} \tag{3.22}$$

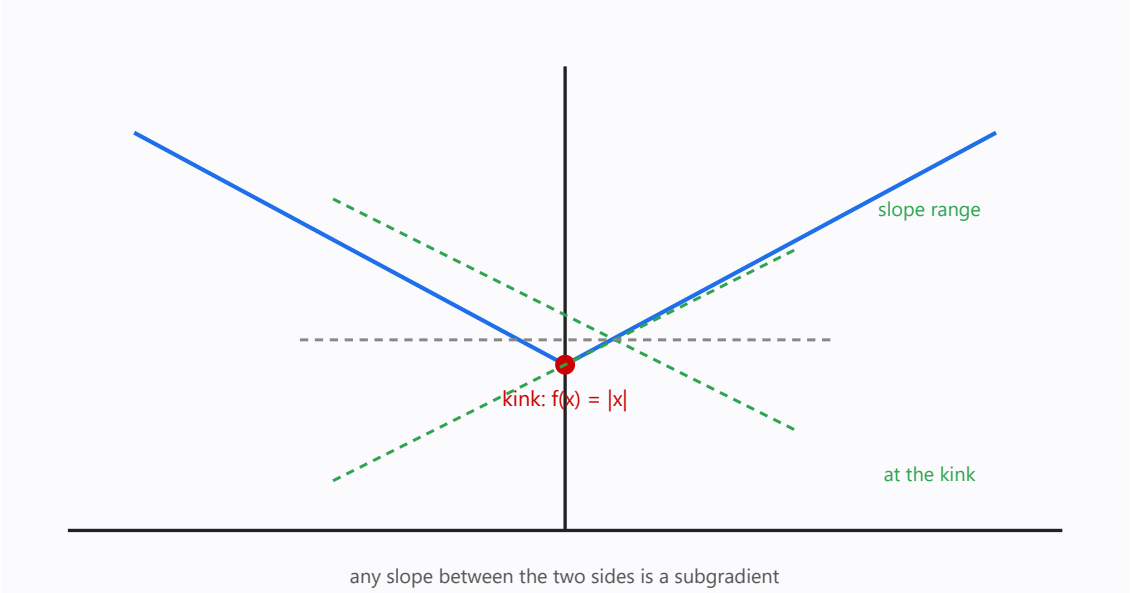
و $0 \in \partial f(x^\star) \iff x^\star$ أصغرى عالمية.

جدول الرموز

الرمز	المعنى
$\partial f(x)$	مجموعة التدرّجات الجزئية
g	تدرّج جزئي
$0 \in \partial f$	شرط الأمثلية
سلسة	$\partial f = \{\nabla f\}$

الرسم

<figure> الشكل<figcaption> 3.22: عند الزاوية لا يوجد مماسّ وحيد؛ كلّ ميل بين الجانبين تدرّج



شكل ٣.٢٢: *
التدرج الجزئي لدالة غير سلسة

جزئي.</figcaption> </figure>

البرهان (مخطّط).

وجود $\partial f \neq \emptyset$ في النقاط الداخلية للمجال (مبرهنة وجود التدرّج الجزئي). شرط الأمثلية: إن كان $0 \in \partial f(x^\star)$ فبتعريف (3.22) مع $g = 0$: $f(y) \geq f(x^\star)$ لكلّ y. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.22): $|x|$ عند الصفر المعطيات: $f(x) = |x|$، $x = 0$. المطلوب: $\partial f(0)$. الحل: الخطوة 1: نحتاج $gy \geq |y|$ لكلّ y $\Rightarrow |g| \leq 1$. النتيجة: $\partial f(0) = [-1, 1]$. الربط بالذكاء الاصطناعي: L1 غير سلسة عند الصفر.

مثال (2-4.22): $|x|$ خارج الصفر المعطيات: $x > 0$. المطلوب: $\partial f(x)$. الحل: الخطوة 1: وحيد هو $\operatorname{sign}(x) = 1$. النتيجة: $\{1\}$. الربط بالذكاء الاصطناعي: القصّ الناعم يشتقّ من هنا.

مثال (3-4.22): شرط الأمثلية المعطيات: $f(x) = |x| + \frac{1}{2}(x-3)^2$. المطلوب: الحلّ. الحل: الخطوة 1: $0 \in \partial f$ $\Rightarrow 0 \in \operatorname{sign}(x) + (x-3)$. الخطوة 2: عند $x = 2$: $0 \in [-1, 1] + (-1) \Rightarrow 0 \in [-2, 0]$ ✓. النتيجة: $x^\star = 2$. الربط بالذكاء الاصطناعي: لاسو بشرط تدرّج جزئي.

مثال (4-4.22): hinge المعطيات: $\max(0, 1 - z)$. المطلوب: التدرّج الجزئي عند $z = 1$. الحل: الخطوة 1: $[-1, 0]$ (بين ميل القطعتين). النتيجة: غير وحيد. الربط بالذكاء الاصطناعي: SVM بنقاط على الهامش.

مثال (5-4.22): دالّة المؤشّر المعطيات: $I_C(x) = 0$ إن $x \in C$ وإلا ∞. المطلوب: ∂I_C. الحل: الخطوة 1: المخروط العمودي $N_C(x)$ عند الحدود، و $\{0\}$ داخلها. النتيجة: مرتبط بالقيود. الربط بالذكاء الاصطناعي: صياغة القيود بالتدرّج الجزئي.

مثال (6-4.22): هبوط التدرّج الجزئي المعطيات: نريد تقليل غير سلس. المطلوب: التحديث. الحل: الخطوة 1: $x_{k+1} = x_k - \eta g_k$ بـ $g_k \in \partial f(x_k)$. الخطوة 2: قد لا ينقص رتيباً، نأخذ أفضل نقطة زيارة. النتيجة: تقارب أبطأ من السلس. الربط بالذكاء الاصطناعي: لماذا لا نعتمد هبوطاً جزئياً خاماً.

مثال (7-4.22): مقارنة بالسلس المعطيات: f سلسة. المطلوب: ∂f. الحل: الخطوة 1: $\{\nabla f(x)\}$ وحيد. النتيجة: التدرّج الجزئي يعمّم التدرّج. الربط بالذكاء الاصطناعي: توحيد النظريتين.

مثال (8-4.22): الأعظمي المعطيات: $f = \max_i f_i$ سلسة. المطلوب: ∂f. الحل: الخطوة 1: غلاف محدّب لتدرّجات الحدود النشطة. النتيجة: $\operatorname{conv}\{\nabla f_i : i \in \mathcal{A}(x)\}$. الربط بالذكاء الاصطناعي: الشبكات/ReLU التفرّعية.

مثال (9-4.22): النُرم L1 في بعدين المعطيات: $\|x\|_1$ عند $(0, 1)$. المطلوب: ∂f. الحل: الخطوة 1: الإحداثي الأول $[-1, 1]$، الثاني $\{1\}$. النتيجة: $\{1\} \times [-1, 1]$. الربط بالذكاء الاصطناعي: تناثر الإحداثيات.

مثال (10-4.22): القصّ الناعم المعطيات: نريد حلّ $\min \frac{1}{2}(x - z)^2 + \lambda|x|$. المطلوب: الحلّ. الحل: الخطوة 1: $0 \in (x - z) + \lambda \operatorname{sign}(x) \Rightarrow x = \operatorname{sign}(z)\max(|z| - \lambda, 0)$. النتيجة: soft-thresholding. الربط بالذكاء الاصطناعي: جوهر لاسو و ISTA (7.22).

مثال (11-4.22): التدرّج الجزئي لا يعطي هبوطاً المعطيات: $g \in \partial f(x)$ بـ $-g$ ليس هبوطاً بالضرورة. المطلوب: التفسير. الحل: الخطوة 1: بخلاف السلس، $-g$ قد لا ينقص القيمة. النتيجة: لا بحث خطّي بسيط. الربط بالذكاء الاصطناعي: تحذير عملي.

مثال (12-4.22): القاعدة لجمع المعطيات: $f + g$ محدّبتان. المطلوب: $\partial(f+g)$. الحل: الخطوة 1: $\partial f + \partial g$ (جمع مجموعات) تحت شروط. النتيجة: قاعدة حسابية. الربط بالذكاء الاصطناعي: خسارة + تنظيم L1.

مثال (13-4.22): النُرم الأعظمي المعطيات: $\|x\|_\infty$ عند تعادل. المطلوب: ∂f. الحل: الخطوة 1: غلاف محدّب لمتّجهات الإحداثيات العظمى. النتيجة: غير وحيد عند التعادل. الربط بالذكاء الاصطناعي: قيود صندوقية/متانة.

مثال (14-4.22): النُرم النووي المعطيات: $\|X\|_*$ مجموع القيم المفردة. المطلوب: التدرّج الجزئي. الحل: الخطوة 1: غلاف محدّب $uv^\top$ للأزواج المفردة العظمى (من الفصل 4). النتيجة: أساس إكمال المصفوفة. الربط بالذكاء

الاصطناعي: التصفية التعاونية/تقليل الرتبة.

مثال (15-4.22): متى يكفي التدرّج الجزئي المعطيات: نريد ضماناً. المطلوب: الحكم. الحل: الخطوة 1: للمحدّب غير السلس يكفي شرط $0 \in \partial f$. النتيجة: أمثلية مضمونة رغم انعدام الاشتقاق. الربط بالذكاء الاصطناعي: التحقّق العملي من الحلول المتناثرة.

أخطاء شائعة

- توقّع نقصان رتيب في هبوط التدرّج الجزئي.
- نسيان أنّ ∂f مجموعة لا متّجه.
- استخدام التدرّج العادي عند الزوايا.
- الخلط بين التدرّج الجزئي والمؤثّر القريب.

$$f^\star(y) \;=\; \sup_{x} \big\{ y^\top x - f(x) \big\}, \qquad f^{\star\star} = f \;\; (\text{إن } f \text{ محدّبة مغلقة}) \tag{4.22}$$

و **متراجحة فنشل-يونغ**: $f(x) + f^\star(y) \geq x^\top y$.

جدول الرموز

الرمز	المعنى
$f^\star$	الدالّة المترافقة
sup	الأعظمي الأعلى
$f^{\star\star}$	المترافق المزدوج
مغلقة	محدّبة وأشباه متّصلة سفلياً

الرسم

<figure> الشكل<figcaption> 4.22: $f^\star(y)$ هي أكبر فرق بين الخطّ المائل $y^\top x$ والدالّة f</figcaption>. </figure>

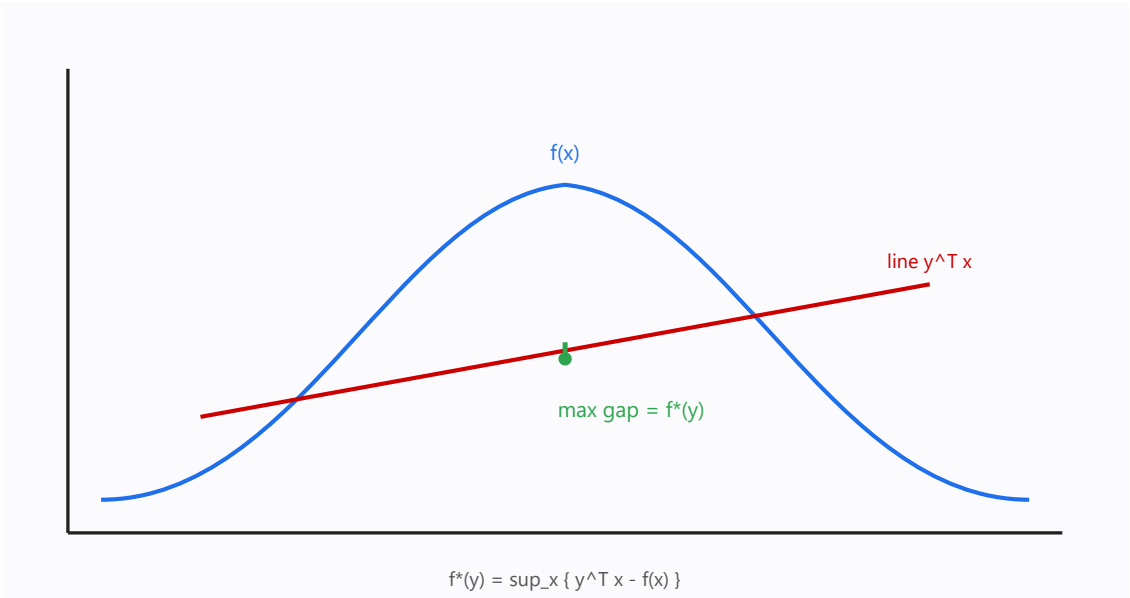
البرهان (مخطّط)

$f^\star$ هي sup لتآلفيات في $y \Rightarrow$ محدّبة مغلقة دائماً. $f^{\star\star}$ هو الغلاف المحدّب المغلق لـ f، فإذا كانت f محدّبة مغلقة فهو f نفسه. متراجحة يونغ من التعريف مباشرة. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.22): التربيعي المعطيات: $f(x) = \frac{1}{2}x^2$. المطلوب: $f^\star(y)$. الحل: الخطوة 1: نعظّم $yx - \frac{1}{2}x^2 \Rightarrow$ المشتقّة $y - x = 0 \Rightarrow y = x$. الخطوة 2: $f^\star = \frac{1}{2}y^2$. النتيجة: نفسها (ذاتية الترافق). الربط بالذكاء الاصطناعي: النُرم التربيعي ذاتي الترافق.

مثال (2-5.22): الأسّي المعطيات: $f(x) = e^x$. المطلوب: $f^\star(y)$. الحل: الخطوة 1: $y > 0 \Rightarrow x = \log y$. الخطوة 2: $f^\star = y\log y - y$. النتيجة: الإنتروبيا السالبة. الربط بالذكاء الاصطناعي: متراقف الأسّي = إنتروبيا (الفصل 26).



شكل ٤.٢٢: *
الازدواج المترافق فنشل

مثال (3-5.22): النُرم المعطيات: $f(x) = \|x\|$. المطلوب: $f^\star(y)$. الحل: الخطوة 1: مترافق النُرم = مؤشّر نُرم الوحدة الثنائي. النتيجة: $I_{\{y:\|y\|_* \le 1\}}$. الربط بالذكاء الاصطناعي: التنظيم كمؤشّر في الثنائية.

مثال (4-5.22): مترابحة يونغ المعطيات: $f = \frac{1}{2}x^2$. المطلوب: التحقّق. الحل: الخطوة 1: $\frac{1}{2}x^2 + \frac{1}{2}y^2 \ge xy$ (من $(x-y)^2 \ge 0$). النتيجة: المترابحة. الربط بالذكاء الاصطناعي: حدود في تحليل التقارب.

مثال (5-5.22): المترافق المزدوج المعطيات: f محدّبة مغلقة. المطلوب: $f^{\star\star}$. الحل: الخطوة 1: يساوي f. النتيجة: تناظر تامّ. الربط بالذكاء الاصطناعي: استرجاع الأولى من الثنائية.

مثال (6-5.22): دالّة المؤشّر المعطيات: I_C. المطلوب: $I_C^\star$. الحل: الخطوة 1: $\sup_{x \in C} y^\top x$ = دالّة الدعم $\sigma_C(y)$. النتيجة: مترافق المؤشّر = الدعم. الربط بالذكاء الاصطناعي: ربط بالمستويات الداعمة (2.22).

مثال (7-5.22): اللوغاريتم السالب المعطيات: $f(x) = -\log x$ على $x > 0$. المطلوب: $f^\star(y)$. الحل: الخطوة 1: $y < 0$: $x = -1/y \Rightarrow f^\star = -1 - \log(-y)$. النتيجة: مترافق معروف. الربط بالذكاء الاصطناعي: يظهر في ثنائيات الإنتروبيا.

مثال (8-5.22): التحجيم المعطيات: $g(x) = af(x)$ بـ $a > 0$. المطلوب: $g^\star(y)$. الحل: الخطوة 1: $af^\star(y/a)$. النتيجة: قاعدة القياس. الربط بالذكاء الاصطناعي: ضبط معلمة التنظيم.

مثال (9-5.22): الإزاحة المعطيات: $g(x) = f(x-b)$. المطلوب: $g^\star(y)$. الحل: الخطوة 1: $f^\star(y) + b^\top y$. النتيجة: قاعدة النقل. الربط بالذكاء الاصطناعي: انحيازات النموذج.

مثال (10-5.22): الترافق واللاغرانجي المعطيات: الثنائية من 4.21. المطلوب: العلاقة. الحل: الخطوة 1: الثنائية المترافقة تعمّم اللاغرانجية. النتيجة: إطار أوسع. الربط بالذكاء الاصطناعي: توحيد الثنائيات.

مثال (11-5.22): L1 مترافقاً المعطيات: $f = \lambda\|x\|_1$. المطلوب: $f^\star$. الحل: الخطوة 1: مؤشّر الصندوق $\|y\|_\infty \le \lambda$. النتيجة: ثنائية لاسو (من 4.21). الربط بالذكاء الاصطناعي: تفسير تناثر لاسو.

مثال (12-5.22): المجموع المنفصل (infimal convolution) المعطيات: $(f \square g)(x) = \inf_u\{f(u) + g(x-u)\}$. المطلوب: المترافق. الحل: الخطوة 1: $(f \square g)^\star = f^\star + g^\star$. النتيجة: الالتفاف الأدنى يترافق مع الجمع. الربط بالذكاء الاصطناعي: envelope Moreau (7.22).

مثال (13-5.22): مترافق غير محدّب المعطيات: f غير محدّبة. المطلوب: النتيجة. الحل: الخطوة 1: $f^{\star\star}$ يعطي

الغلاف المحدّب المغلق لا f. النتيجة: استرخاء محدّب. الربط بالذكاء الاصطناعي: استرخاءات في التحسين.

مثال (5.22-14): الترافق في التعلم العميق المعطيات: نماذج الطاقة (EBM). المطلوب: الاستخدام. الحل: الخطوة 1: اللوغاريتم الطبيعي يرتبط بالمترافق الأسّي. النتيجة: تدريب EBM بصورة مترافقة. الربط بالذكاء الاصطناعي: models. energy-based

مثال (5.22-15): لماذا المترافق مهمّ المعطيات: نريد حدوداً ونظرية. المطلوب: الفائدة. الحل: الخطوة 1: يحول المسائل إلى صيغة خطّية/مؤشّر أسهل. النتيجة: أداة تحليل مركزية. الربط بالذكاء الاصطناعي: أساس الخوارزميات القريبة.

أخطاء شائعة

- نسيان أنّ $f^\star$ محدّبة مغلقة دائماً حتى لو لم تكن f كذلك.
- الخلط بين $f^\star$ (مترافق) و $f^\star$ (القيمة المثلى).
- افتراض $f = f^{\star\star}$ لغير المحدّب.
- تجاهل أنّ $f^\star$ قد تكون ∞ خارج مجال.

لمسألة $\min_x f(x) + g(Ax)$، الثنائية هي $\max_y -f^\star(-A^\top y) - g^\star(y)$:

$$p^\star = \min_x \{f(x) + g(Ax)\}, \qquad d^\star = \max_y \{ -f^\star(-A^\top y) - g^\star(y)\} \tag{5.22}$$

وتحت شروط تأهّل (مثل وجود نقطة داخلية) تكون الثنائية قوية: $p^\star = d^\star$.

جدول الرموز

الرمز	المعنى
A	مؤثّر خطّي يربط الحدّين
f, g	محدّبتان مغلقتان
$-A^\top y$	انتقال المترافق
تأهّل	شرط نقطة داخلية

الرسم

<figure> الشكل<figcaption> 5.22: الثنائية تعظّم على y باستخدام مترافقي الحدّين؛ الفجوة صفر تحت التأهّل.</figcaption> </figure>

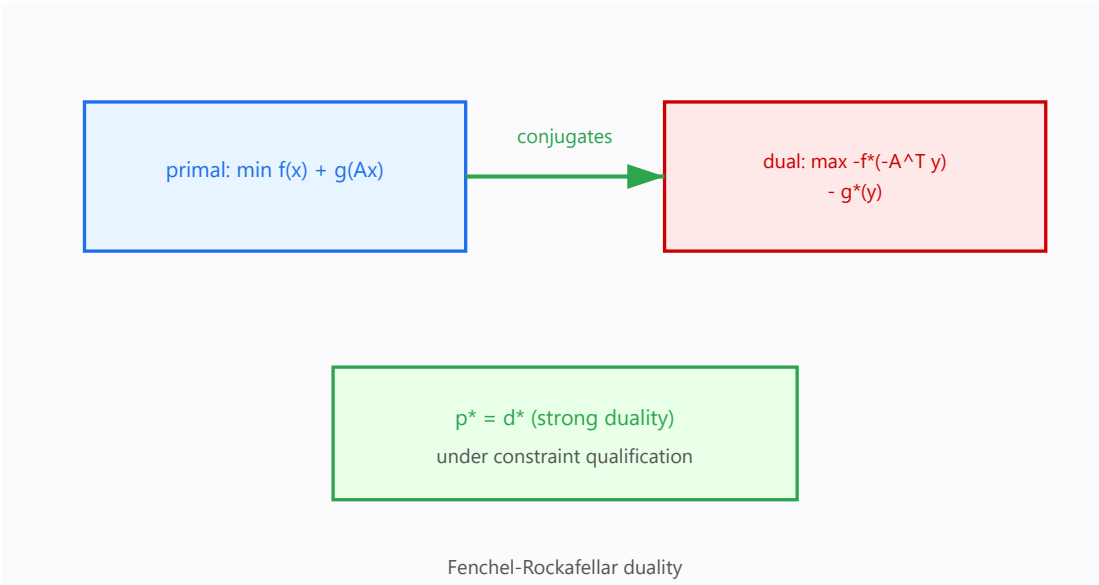
البرهان (مخطّط)

نعيد كتابة المسألة كـ $\min_{x,z}\{f(x) + g(z) : Ax = z\}$، ونطبّق اللاغرانجي (4.21) بمضاعف y: $g_{dual}(y) = \inf_x\{f(x) + y^\top Ax\} + \inf_z\{g(z) - y^\top z\} = -f^\star(-A^\top y) - g^\star(y)$. التأهّل يضمن قوّة الثنائية. ■

خمسة عشر مثالاً محلولاً

مثال (6.22-1): الصياغة المعطيات: $\min f(x) + g(Ax)$. المطلوب: الثنائية. الحل: الخطوة 1: بالتعريف (5.22). النتيجة: الثنائية المترافقة. الربط بالذكاء الاصطناعي: إطار يوحّد مسائل كثيرة.

مثال (6.22-2): استرجاع لاسو المعطيات: لاسو بـ $A = I$. المطلوب: الثنائية. الحل: الخطوة 1: $-f^\star(-y) - g^\star(y)$ تعطي ثنائية الصندوق. النتيجة: يطابق 4.21-13. الربط بالذكاء الاصطناعي: تناسق النظريات.



شكل ٥.٢٢: *
ازدواج فنشل روكافلر

مثال (3-6.22): شرط التأهّل المعطيات: نريد ثنائية قوية. المطلوب: الشرط. الحل: الخطوة 1: وجود نقطة داخلية نسبية (تعليل سلاتر من 5.21). النتيجة: لا فجوة. الربط بالذكاء الاصطناعي: ضمانات للمحسّنات.

مثال (4-6.22): استرجاع الأولى المعطيات: حلّ ثنائي $y^\star$. المطلوب: $x^\star$. الحل: الخطوة 1: من شرط التعادل في مترابحة يونغ: $-A^\top y^\star \in \partial f(x^\star)$. النتيجة: استرجاع صريح. الربط بالذكاء الاصطناعي: استخراج الحلّ من الثنائية.

مثال (5-6.22): SVM من فنشل المعطيات: hinge + نُرم. المطلوب: الثنائية. الحل: الخطوة 1: يعطي ثنائية SVM المعروفة (من 8.21). النتيجة: تناسق مع 6-4.21. الربط بالذكاء الاصطناعي: وحدة النظرية.

مثال (6-6.22): التركيب مع المؤشّر المعطيات: $g = I_C$. المطلوب: الثنائية. الحل: الخطوة 1: $g^\star = \sigma_C$ دالّة الدعم. النتيجة: قيود تتحوّل لدعم. الربط بالذكاء الاصطناعي: قيود محدّبة عامّة.

مثال (7-6.22): الفجوة في غير المحدّب المعطيات: f غير محدّبة. المطلوب: النتيجة. الحل: الخطوة 1: قد تظهر فجوة موجبة. النتيجة: استرخاء لا مساواة. الربط بالذكاء الاصطناعي: حدود الطرق الثنائية.

مثال (8-6.22): معيار توقّف بالفجوة المعطيات: نحسب أولياً وثنائياً. المطلوب: القرار. الحل: الخطوة 1: نتوقّف حين $p - d \le \epsilon$. النتيجة: ضمان كمّي. الربط بالذكاء الاصطناعي: جودة الحلّ.

مثال (9-6.22): تفكيك الحدّين المعطيات: f سلسة و g غير سلسة. المطلوب: الفائدة. الحل: الخطوة 1: نعالج كلّاً بطريقته (تدرّج وقريب). النتيجة: أساس النزول القريب (7.22). الربط بالذكاء الاصطناعي: خسارة سلسة + تنظيم L1.

مثال (10-6.22): النقل الأمثل تمهيداً المعطيات: نقل كتلة بقيود هامشية. المطلوب: الصياغة. الحل: الخطوة 1: مسألة خطّية بقيود $\Rightarrow$ ثنائية مترافقة (الفصل 42). النتيجة: تمهيد للنقل الأمثل. الربط بالذكاء الاصطناعي: GAN. Wasserstein

مثال (11-6.22): ADMM من فنشل المعطيات: تقسيم المتغيّرات. المطلوب: العلاقة. الحل: الخطوة 1: ADMM يحلّ صيغة «$f(x) + g(z)$ بشرط $x = z$» (من 7.21). النتيجة: يطابق إطار فنشل. الربط بالذكاء الاصطناعي: وحدة الخوارزميات.

مثال (12-6.22): شروط التعادل المعطيات: الحلّ المثلي. المطلوب: الشروط. الحل: الخطوة 1: $-A^\top y^\star \in \partial f(x^\star)$ و $y^\star \in \partial g(Ax^\star)$. النتيجة: تعميم KKT. الربط بالذكاء الاصطناعي: تحقّق من الأمثلية.

مثال (13-6.22): مثال عددي بسيط المعطيات: $f=\frac{1}{2}x^2$، $g=|z|$، $A=1$. المطلوب: الثنائية. الحل: الخطوة 1: $f^\star=\frac{1}{2}y^2$، $g^\star=I_{[-1,1]}$. الخطوة 2: الثنائية $\max_{|y|\le 1}-\frac{1}{2}y^2=0$ عند $y=0$. النتيجة: $p^\star=d^\star=0$ (الحلّ $x=0$). الربط بالذكاء الاصطناعي: تحقّق يدوي.

مثال (14-6.22): التناظر المعطيات: نبدّل الأدوار. المطلوب: الملاحظة. الحل: الخطوة 1: الثنائية المترافقة متناظرة بين الأولى والثنائية. النتيجة: أناقة النظرية. الربط بالذكاء الاصطناعي: فهم أعمق.

مثال (15-6.22): لماذا نستخدمه المعطيات: نريد خوارزمية وحدوداً. المطلوب: الفائدة. الحل: الخطوة 1: يفكك المسألة ويعطي شهادة أمثلية. النتيجة: نظرية + خوارزمية معاً. الربط بالذكاء الاصطناعي: تصميم المحسّنات.

أخطاء شائعة

- نسيان شرط التأهّل قبل ادّعاء القوّة.
- الخلط بين إشارة $A^\top y$ و $-A^\top y$.
- افتراض استرجاع الأولى دون تعادل في يونغ.
- تجاهل أنّ f,g يجب أن تكونا محدّبتين مغلقتين.

المؤثّر القريب لدالّة محدّبة g بخطوة $\gamma>0$:

$$\operatorname{prox}_{\gamma g}(v)=\arg\min_x\Big\{g(x)+\frac{1}{2\gamma}\|x-v\|^2\Big\},\qquad x_{k+1}=\operatorname{prox}_{\eta g}\big(x_k-\eta\nabla f(x_k)\big) \tag{6.22}$$

الصيغة الأخيرة هي **خوارزمية النزول القريب** (ISTA) لمسألة $\min f+g$.

جدول الرموز

الرمز	المعنى
$\operatorname{prox}_{\gamma g}$	المؤثّر القريب
γ,η	معلمة القرب / الخطوة
f	سلسة بـ L
g	محدّبة غير سلسة (كـ L1)

الرسم

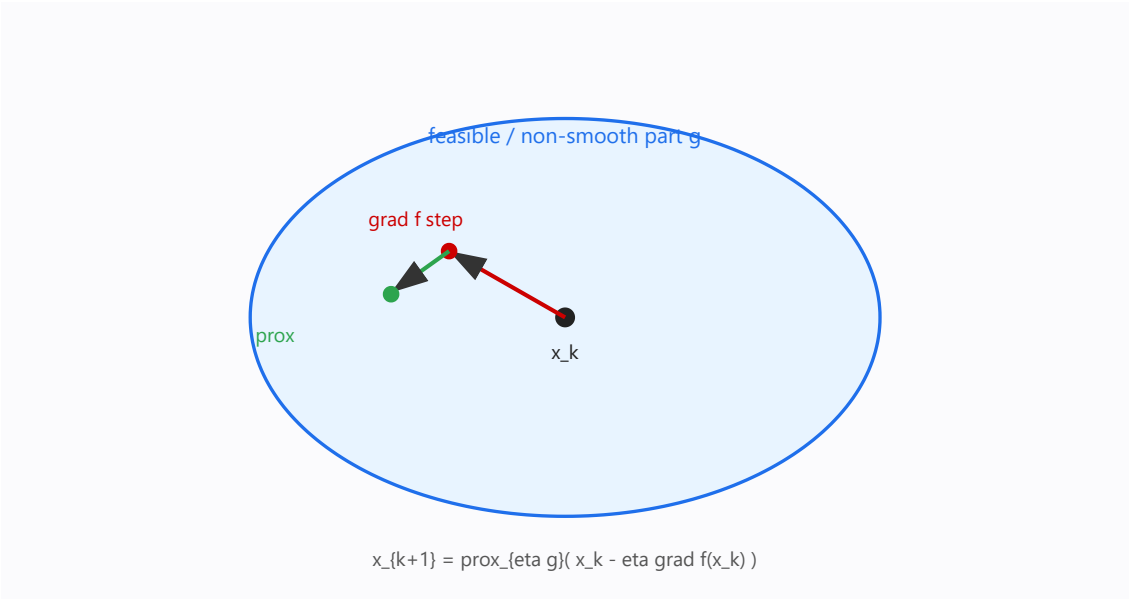
<figure> الشكل<figcaption> 6.22: خطوة تدرّج على f السلسة ثمّ خطوة قريبة على g غير السلسة.</figcaption>
</figure>

البرهان (مخطّط)

نوسّع f تايلور (من الفصل 11): $f(x)\approx f(x_k)+\nabla f^\top(x-x_k)+\frac{1}{2\eta}\|x-x_k\|^2$؛ بإكمال المربّع نحصل على تحديث $\operatorname{prox}_{\eta g}(x_k-\eta\nabla f(x_k))$. التقارب $O(1/k)$ للقيمة، بخطوة $\eta\le 1/L$. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.22): التعريف المعطيات: $g=\lambda|x|$. المطلوب: $\operatorname{prox}_{\gamma g}(v)$. الحل: الخطوة 1: حلّ $\min \lambda|x|+\frac{1}{2\gamma}(x-v)^2$. الخطوة 2: القصّ الناعم $\operatorname{sign}(v)\max(|v|-\gamma\lambda,0)$. النتيجة: soft-thresholding (من 10-4.22). الربط بالذكاء الاصطناعي: جوهر تناثر لاسو.



شكل ٦.٢٢: *
المؤثر القريب وخوارزمية النزول القريب

مثال (2-7.22): القرب للإسقاط المعطيات: $g = I_C$. المطلوب: $\text{prox}_{\gamma g}$. الحل: الخطوة 1: $\min_{x \in C} \|x - v\|^2 \Rightarrow$ الإسقاط $\Pi_C(v)$ (من 6.21). النتيجة: الإسقاط حالة خاصّة. الربط بالذكاء الاصطناعي: توحيد المفاهيم.

مثال (3-7.22): تكرار ISTA المعطيات: $\min \frac{1}{2}\|Ax - b\|^2 + \lambda\|x\|_1$. المطلوب: التحديث. الحل: الخطوة 1: $z = x - \eta A^\top(Ax - b)$. الخطوة 2: $x_+ = \text{soft}(z, \eta\lambda)$. النتيجة: خوارزمية لاسو التكرارية. الربط بالذكاء الاصطناعي: تدريب نماذج متناثرة.

مثال (4-7.22): اختيار الخطوة المعطيات: $L = \lambda_{\max}(A^\top A)$. المطلوب: η. الحل: الخطوة 1: $\eta \le 1/L$ (من 5.20). النتيجة: تقارب مضمون. الربط بالذكاء الاصطناعي: ضبط عملي.

مثال (5-7.22): معدّل التقارب المعطيات: محدّب بجزء سلس. المطلوب: المعدّل. الحل: الخطوة 1: $O(1/k)$ لقيمة الهدف. النتيجة: أبطأ من الخطّي لكن كافٍ. الربط بالذكاء الاصطناعي: ميزانية التكرارات.

مثال (6-7.22): القرب للنُرم النووي المعطيات: $g = \lambda\|X\|_*$. المطلوب: prox. الحل: الخطوة 1: قصّ ناعم على القيم المفردة (من 14-4.22). النتيجة: إكمال مصفوفة. الربط بالذكاء الاصطناعي: تقليل الرتبة/التوصية.

مثال (7-7.22): القرب لـ L2 المعطيات: $g = \frac{\lambda}{2}\|x\|^2$. المطلوب: prox. الحل: الخطوة 1: $\frac{v}{1+\gamma\lambda}$ (انكماش). النتيجة: ريدج نخطوة قريبة. الربط بالذكاء الاصطناعي: decay weight قريب.

مثال (8-7.22): عدم تمدّد القرب المعطيات: u, v. المطلوب: الخاصّية. الحل: الخطوة 1: $\|\text{prox}(u) - \text{prox}(v)\| \le \|u - v\|$. النتيجة: استقرار عددي. الربط بالذكاء الاصطناعي: أمان التنفيذ.

مثال (9-7.22): مغلقة الشكل أم لا المعطيات: prox غير مغلق أحياناً. المطلوب: المعالجة. الحل: الخطوة 1: نحلّ المسألة الفرعية تكرارياً أو نقرّبها. النتيجة: prox غير دقيق (inexact). الربط بالذكاء الاصطناعي: prox لخسائر معقّدة.

مثال (10-7.22): ظرف مورو (Moreau) المعطيات: $M_{\gamma g}(v) = \min_x\{g(x) + \frac{1}{2\gamma}\|x - v\|^2\}$. المطلوب: الخاصّيات. الحل: الخطوة 1: سلسة وتدرّجها $\frac{1}{\gamma}(v - \text{prox}_{\gamma g}(v))$. النتيجة: تنعيم محدّب. الربط بالذكاء الاصطناعي: تنعيم الخسائر غير السلسة.

مثال (11-7.22): مقارنة بالتدرّج الجزئي المعطيات: نقارن الطريقتين لغير السلس. المطلوب: أيهما أفضل؟ الحل: الخطوة 1: القريب أسرع وأكثر استقراراً (يستغلّ الحدّ السلس). النتيجة: تفضيل القريب. الربط بالذكاء الاصطناعي: لماذا نستخدم prox بدل subgradient.

مثال (12-7.22): تطبيق في الرؤية المعطيات: استعادة صورة .(denoising/deblur) المطلوب: النموذج. الحل: الخطوة 1: $\frac{1}{2}\|Ax - b\|^2 + \lambda\|Dx\|_1$ (تناثر في التدرّجات). النتيجة: تنعيم محافظ على الحدود. الربط بالذكاء الاصطناعي: معالجة الصور/الترميم.

مثال (13-7.22): القرب على المبسّط المعطيات: قيد احتمالات. المطلوب: .prox الحل: الخطوة 1: إسقاط على المبسّط (من 3-6.21). النتيجة: تحديث يحفظ التوزيع. الربط بالذكاء الاصطناعي: توزيعات softmax مقيّدة.

مثال (14-7.22): التقارب العملي المعطيات: نشاهد تقارباً بطيئاً. المطلوب: التشخيص. الحل: الخطوة 1: معدّل $O(1/k)$ طبيعي؛ نحتاج تسريعاً (8.22). النتيجة: الانتقال لـ .FISTA الربط بالذكاء الاصطناعي: تسريع الاستدلال/التدريب.

مثال (15-7.22): ISTA والشبكات المعطيات: unrolling شبكة من تكرارات .ISTA المطلوب: الفكرة. الحل: الخطوة 1: كلّ تكرار يصير طبقة $\Rightarrow$ .LISTA النتيجة: شبكة بتحيّز تحليلي قوي. الربط بالذكاء الاصطناعي: algorithm networks. unfolded deep / unrolling

أخطاء شائعة

- استخدام $\eta > 1/L$ فيتباعد.
- الخلط بين القرب (prox) والإسقاط في غير المؤشّر.
- نسيان أنّ الخطوة القريبة تعاقب الابتعاد عن v.
- توقّع تقارب خطّي بدون تحدّب قوي.

نسخة نيستروف المسرّعة من النزول القريب تستخدم متغيّراً مساعداً y_k:

$$x_k = \operatorname{prox}_{\eta g}\big(y_{k-1} - \eta \nabla f(y_{k-1})\big), \quad y_k = x_k + \frac{t_{k-1}-1}{t_k}(x_k - x_{k-1}), \quad t_{k+1} = \frac{1+\sqrt{1+4t_k^2}}{2} \tag{7.22}$$

فيتحسّن المعدّل من $O(1/k)$ إلى $O(1/k^2)$.

جدول الرموز

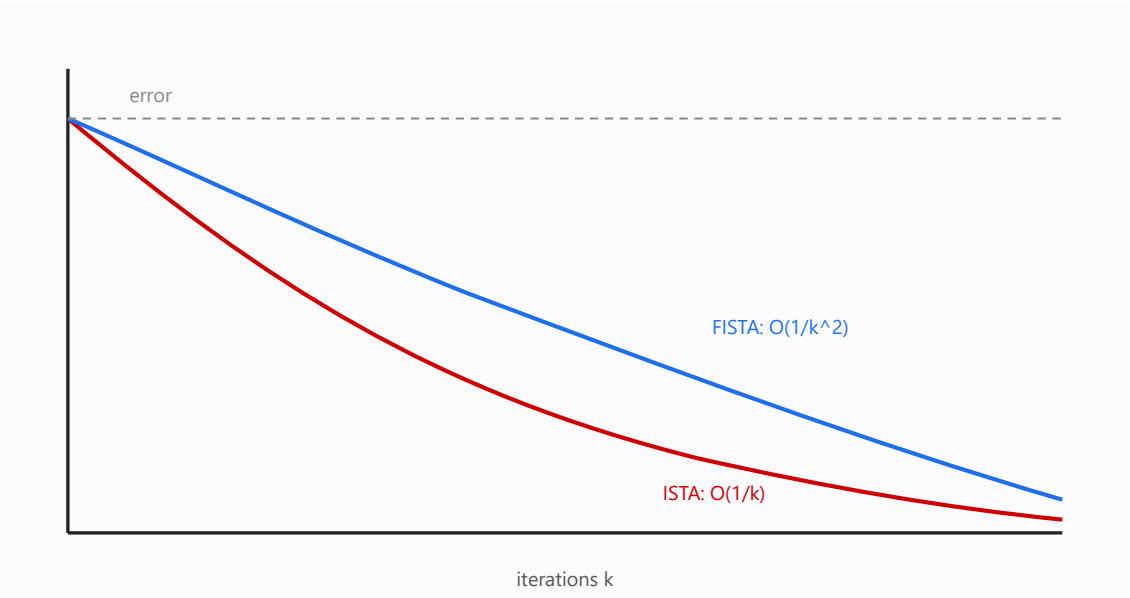
الرمز	المعنى
y_k	نقطة الاستباق (extrapolation)
t_k	معامل نيستروف
$O(1/k^2)$	معدّل مسرّع
زخم	الفرق $(x_k - x_{k-1})$ بوزن

الرسم

<figure> الشكل<figcaption> 7.22: الاستباق من y_k يحفظ الزخم فيقلّص الخطأ كـ $O(1/k^2)$ بدل $O(1/k)$.</figcaption></figure>

البرهان (مخطّط)

بناء مبرهنة «تسلسل التقدير» (estimate sequence) لنيستروف: نحافظ على حدّ سفلي مكعّب التحديث يتقلّص بعامل $(1 - 1/t_k)$، وباختيار $t_k \approx k/2$ نحصل على تراكم يعطي $O(1/k^2)$ للقيمة. ■



شكل ٧.٢٢: *
تسريع FISTA ومعدل التقارب

خمسة عشر مثالاً محلولاً

مثال (1-8.22): الفكرة المعطيات: نريد تسريع ISTA. المطلوب: المبدأ. الحل: الخطوة 1: نقيّم التدرّج في نقطة مستبقة y لا في x. النتيجة: زخم مدمج. الربط بالذكاء الاصطناعي: momentum Nesterov عملياً.

مثال (2-8.22): تحديث t_k المعطيات: $t_0 = 1$. المطلوب: التسلسل. الحل: الخطوة 1: $t_1 = \frac{1+\sqrt{5}}{2} \approx 1.618$، ويغو $k/2 \approx$. النتيجة: معامل متزايد. الربط بالذكاء الاصطناعي: جدولة الزخم.

مثال (3-8.22): حساب الاستباق المعطيات: $t_{k-1} = 2$، $t_k = 2.5$. المطلوب: الوزن. الحل: الخطوة 1: $\frac{2-1}{2.5} = 0.4$. النتيجة: $y_k = x_k + 0.4(x_k - x_{k-1})$. الربط بالذكاء الاصطناعي: صيغة جاهزة للتنفيذ.

مثال (4-8.22): مقارنة المعدّلين المعطيات: $k = 100$. المطلوب: الفرق. الحل: الخطوة 1: $1/100$ مقابل $1/10000 \Rightarrow$ أفضل بـ 100 مرة. النتيجة: فرق هائل. الربط بالذكاء الاصطناعي: لماذا التسريع يستحقّ.

مثال (5-8.22): FISTA للاسو المعطيات: نفس مسألة 3-7.22. المطلوب: التعديل. الحل: الخطوة 1: نطبّق القصّ الناعم في نقطة y المستبقة. النتيجة: لاسو مسرّع. الربط بالذكاء الاصطناعي: حلول متناثرة أسرع.

مثال (6-8.22): إعادة التشغيل (restart) المعطيات: تسارع متذبذب. المطلوب: المعالجة. الحل: الخطوة 1: نعيد تعيين $t_k = 1$ عند تذبذب/تحدّب قوي. النتيجة: تقارب خطّي فعلي. الربط بالذكاء الاصطناعي: تقنيات تسريع حديثة.

مثال (7-8.22): متى لا يتذبذب المعطيات: محدّب سلس خالص بلا L1. المطلوب: السلوك. الحل: الخطوة 1: التسريع أنعم، يقارب الحدّ النظري. النتيجة: أداء مثالي. الربط بالذكاء الاصطناعي: تدريب نماذج محدّبة.

مثال (8-8.22): الحدّ الأدنى النظري المعطيات: نريد حصراً. المطلوب: الحدّ. الحل: الخطوة 1: $O(1/k^2)$ هو الأمثل لطرق الرتبة الأولى على المحدّب السلس. النتيجة: لا مجال لأفضل (بالمعلومات المتاحة). الربط بالذكاء الاصطناعي: تقييم المحسّنات.

مثال (9-8.22): التسريع مع التحدّب القوي المعطيات: نعرف μ, L. المطلوب: المعدّل. الحل: الخطوة 1: نستخدم $\frac{1-\sqrt{\mu/L}}{1+\sqrt{\mu/L}} \Rightarrow$ خطّي أسرع. النتيجة: تقارب خطّي مسرّع. الربط بالذكاء الاصطناعي: ضبط بمعرفة الانحناء.

مثال (10-8.22): الصياغة البديلة المعطيات: نريد صيغة بالزخم β. المطلوب: التحويل. الحل: الخطوة 1:

$\beta_k = \frac{t_{k-1}-1}{t_k}$. النتيجة: تكافؤ مع صيغة الزخم. الربط بالذكاء الاصطناعي: ربط بـ الزخم/Adam (الفصل 23).

مثال (22.8-11): مثال عددي المعطيات: $k = 10$، $t_{10} \approx 5.5$. المطلوب: سرعة التقارب. الحل: الخطوة 1: الحدّ يتقلّص $1/t_{10}^2 \approx 0.033 \approx$. النتيجة: تطابق مع $O(1/k^2)$. الربط بالذكاء الاصطناعي: تحقّق عملي.

مثال (22.8-12): التوقف والاستقرار المعطيات: نلاحظ تذبذباً في الخطوات الأخيرة. المطلوب: التشخيص. الحل: الخطوة 1: طبيعي للتسريع؛ نأخذ أفضل نقطة أو نعيد التشغيل. النتيجة: تفسير سلوك المحسّن. الربط بالذكاء الاصطناعي: تصحيح أخطاء التدريب.

مثال (22.8-13): FISTA مقابل ADMM المعطيات: نقارن لمسألة لاسو. المطلوب: أيهما؟ الحل: الخطوة 1: FISTA أبسط؛ ADMM أفضل في التوزيع/القيود المعقّدة. النتيجة: دليل اختيار. الربط بالذكاء الاصطناعي: هندسة المحسّنات.

مثال (22.8-14): التسريع في الشبكات المعطيات: تدريب عميق بزخم نيستروف. المطلوب: الفائدة. الحل: الخطوة 1: الزخم يخفّف تعرّج الأودية الضيّقة (من 5.20). النتيجة: تقارب أسرع عملياً. الربط بالذكاء الاصطناعي: محسّنات التعلّم العميق.

مثال (22.8-15): خلاصة الجزء المحدّب المعطيات: كلّ ما سبق. المطلوب: الصورة الكاملة. الحل: الخطوة 1: التحدّب $\Rightarrow$ عالمية؛ المترافق $\Rightarrow$ ثنائية؛ القريب $\Rightarrow$ خوارزمية؛ التسريع $\Rightarrow$ كفاءة. النتيجة: منظر موحّد. الربط بالذكاء الاصطناعي: أساس تصميم المحسّنات.

أخطاء شائعة

- تطبيق التسريع على مسائل صاخبة (SGD) بحذر (قد يضرّ).
- نسيان تحديث t_k فيبقى مجرّد زخم ثابت.
- توقّع نقصان رتيب (التسريع قد يتذبذب).
- الخلط بين استباق نيستروف والزخم الثقيل (مختلفان).

ملخّص النظريات

النظرية	المفهوم	الأهمّية
22.2 الفصل	مستوٍ فائق يفصل	أساس SVM والجدوى
22.3 الدوالّ	عمليات حافظة	بناء خسائر محدّبة
22.4 التدرّج الجزئي	$0 \in \partial f$	L1/ReLU غير السلسة
22.5 المترافق	$f^\star = \sup(y^\top x - f)$	تحويل المسائل
22.6 فنشل–روكافلر	$\max -f^\star(-A^\top y) - g^\star(y)$	ثنائيّة عامّة
22.7 القريب	ISTA + prox	خوارزمية لغير السلس
22.8 FISTA	استباق نيستروف	$O(1/k^2)$

عشرون تمريناً (مع إجابات مختصرة)

١. متى يوجد فاصل صارم؟ (C مغلقة محدّبة و $z \notin C$)

٢. هل تقاطع المحدّبات محدّب؟ (نعم)

٣. الدالّة المحدّبة بالرسم الفوقي؟ (epi$f$ محدّب)

٤. هل الأعظمي يحفظ التحدّب؟ (نعم)

٥. $\partial|x|$ عند الصفر؟ ($[-1,1]$)

٦. شرط الأمثلية الجزئية؟ ($0 \in \partial f(x^\star)$)

٧. حلّ القصّ الناعم؟ ($\operatorname{sign}(v)\max(|v|-\gamma\lambda,0)$)

٨. مترافق $\frac{1}{2}x^2$؟ ($\frac{1}{2}y^2$)

٩. مترافق e^x؟ ($y\log y - y$)

١٠. متراجحة يونغ؟ ($f(x)+f^\star(y)\geq x^\top y$)

١١. متى $f = f^{\star\star}$؟ (f محدّبة مغلقة)

١٢. صيغة فنشل–روكافلر؟ ($\max -f^\star(-A^\top y)-g^\star(y)$)

١٣. prox للمؤشّر؟ (الإسقاط Π_C)

١٤. prox لـ $\lambda|x|$؟ (القصّ الناعم)

١٥. أكبر خطوة في ISTA؟ ($\eta \leq 1/L$)

١٦. معدّل ISTA؟ ($O(1/k)$)

١٧. معدّل FISTA؟ ($O(1/k^2)$)

١٨. تحديث t_{k+1}؟ ($\frac{1+\sqrt{1+4t_k^2}}{2}$)

١٩. لماذا نعيد التشغيل؟ (لمنع التذبذب/تحقيق خطّي)

٢٠. مترافق النُرم؟ (مؤشّر النُرم الثنائي)

فهرس الرموز

الرمز	المعنى
C, conv	مجموعة وغلاف محدّب
∂f	التدرّج الجزئي
$f^\star$	المترافق
$\operatorname{prox}_{\gamma g}$	المؤثّر القريب
y_k, t_k	استباق ومعامل نيستروف

مراجع

- Vandenberghe & Boyd — *Convex Optimization*.
- Rockafellar — *Convex Analysis*.
- Beck & Teboulle — «A Fast Iterative Shrinkage-Thresholding Algorithm».
- Nesterov — *Introductory Lectures on Convex Optimization*.

- *Algorithms Proximal* — Boyd & Parikh.

خاتمة: بهذا الفصل تكتمل نظرية التحسين المحدّب. الفصل 23 ينقلنا إلى **خوارزميات التدرّج العشوائية** (SGD والزخم وAdam)، حيث لا نرى التدرّج كاملاً بل نراه بالعيّنات، وتصير الضوضاء جزءاً من الخوارزمية لا عيباً فيها.

خوارزميات التدرّج: SGD، الزخم، Adam، L-BFGS

«الضوضاء ليست عدوّ المحسّن؛ أحياناً هي ما ينقذه من السرج.»

حتى الآن افترضنا أنّنا نرى التدرّج كاملاً. في تعلّم الآلة نادراً ما يكون ذلك ممكناً: ملايين العيّنات، وتقييم التدرّج الكامل يكلّف المرور بكلّ البيانات. الحلّ: **نقدّر التدرّج بعيّنة** فنحصل على الهبوط العشوائي (SGD) — أرخص بمرتبة، وإن كان صاخباً.ثمّ نتعلّم كيف نروّض تلك الضوضاء بالزخم والتكييف وجدولة معدّل التعلّم.
سبع نظريات:

- **2.23 الهبوط العشوائي SGD** — التقدير غير المتحيّز ومعدّل التقارب.
- **3.23 الزخم الثقيل** — تراكم الاتجاه.
- **4.23 تسريع نيستروف** — التقييم في نقطة مستبقة.
- **5.23 الطرق التكيّفية: AdaGrad و RMSProp** — خطوة لكلّ إحداثي.
- **6.23 Adam و AdamW** — الزخم + التكييف + تصحيح الانحياز.
- **7.23 تقليل التباين: SVRG و SAGA** — إلغاء الضوضاء تدريجيّاً.
- **8.23 جدولة معدّل التعلّم والاختيار العملي** — متى نستخدم أيّ محسّن؟

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

نريد تقليل $f(x) = \frac{1}{n}\sum_{i=1}^{n} f_i(x)$. نرسم فهرساً i_k عشوائيّاً ونحسب ∇f_{i_k} بدل ∇f.

الرمز	المعنى
$\hat{g}_k$	تقدير التدرّج العشوائي
η_k	معدّل التعلّم (الخطوة)
β	معامل الزخم
m_k, v_k	اللحظتان الأولى والثانية في Adam
σ^2	تباين تقدير التدرّج

$$x_{k+1} = x_k - \eta_k\, \hat{g}_k, \qquad \mathbb{E}[\hat{g}_k \mid x_k] = \nabla f(x_k), \qquad \min_{k} \mathbb{E}\|\nabla f(x_k)\|^2 = O(1/\sqrt{K}) \tag{1.23}$$

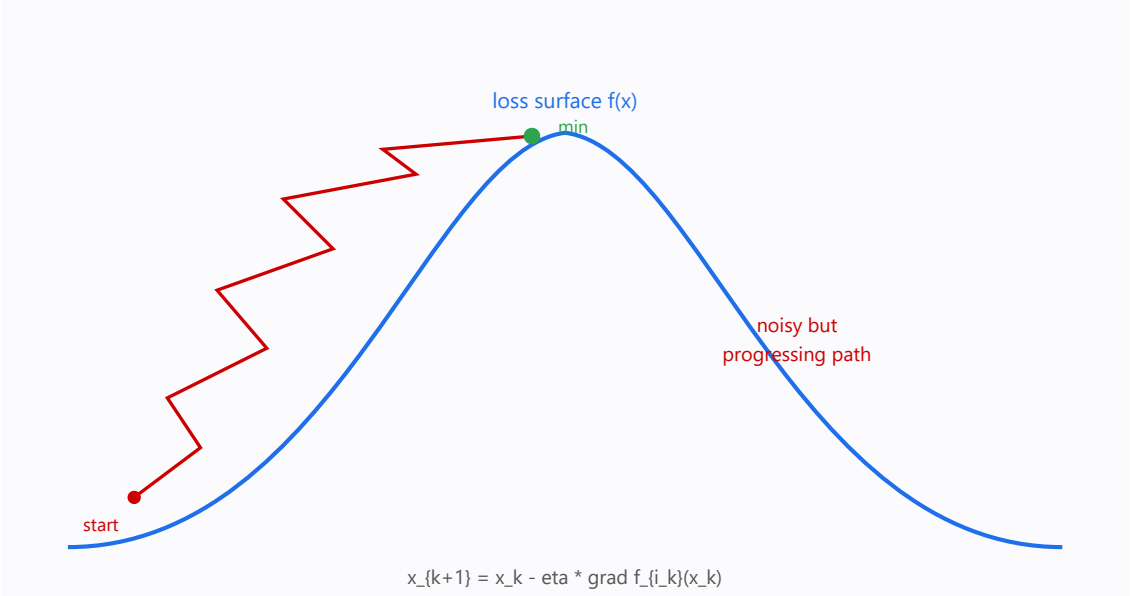
أي بتقليل معدّل التعلّم $\eta_k \propto 1/\sqrt{k}$ نتقارب إلى نقطة حرجة بمعدّل $O(1/\sqrt{K})$.

جدول الرموز

الرمز	المعنى
i_k	الفهرس المرسوم عشوائياً
$\hat{g}_k = \nabla f_{i_k}$	تقدير غير متحيّز
$\eta_k \downarrow$	جدولة متضائلة
$O(1/\sqrt{K})$	معدّل التقارب للمحدّب

الرسم

<figure> الشكل<figcaption> 1.23: كلّ تكرار يستخدم عيّنة واحدة؛ المسار صاخب لكنّه يتقدّم نحو



شكل ١.٢٣: *
الهبوط العشوائي SGD

القاع.</figcaption> </figure>

البرهان (مخطّط)

بمتراجحة الهبوط مع توقّع شرطي: $\mathbb{E}[f(x_{k+1})] \le f(x_k) - \eta(1 - \frac{\eta L}{2})\|\nabla f\|^2 + \frac{\eta^2 L}{2}\sigma^2$. نجمع على k ونقسم على $\sum \eta_k$؛ باختيار $\eta_k \propto 1/\sqrt{k}$ يصير متوسط $\|\nabla f\|^2$ بحدود $O(1/\sqrt{K})$. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.23): التحديث الأساسي المعطيات: $x = 2$، $\hat{g} = 0.5$، $\eta = 0.1$. المطلوب: x_+. الحل: الخطوة 1: $x_+ = 2 - 0.1(0.5) = 1.95$. النتيجة: 1.95. الربط بالذكاء الاصطناعي: تحديث المعاملات بعيّنة/دفعة.

مثال (2-2.23): عدم التحيّز المعطيات: $\hat{g} = \nabla f_i$ بـ i منتظماً. المطلوب: $\mathbb{E}[\hat{g}]$. الحل: الخطوة 1: $\frac{1}{n}\sum_i \nabla f_i = \nabla f$. النتيجة: غير متحيّز. الربط بالذكاء الاصطناعي: لماذا يعمل رغم الضوضاء.

مثال (3-2.23): تباين التقدير المعطيات: تباين $\hat{g}$ هو σ^2. المطلوب: الأثر. الحل: الخطوة 1: يمنع التقارب إلى نقطة دقيقة بخطوة ثابتة. النتيجة: نتوقّف عند «جوار» لا نقطة. الربط بالذكاء الاصطناعي: نحتاج جدولة/تقليل تباين.

مثال (4-2.23): الجدولة المتضائلة المعطيات: $\eta_0/\sqrt{k}$ = η_k. المطلوب: السبب. الحل: الخطوة 1: يخفض

الضوضاء تدريجياً فيسمح بالاستقرار. النتيجة: تقارب إلى نقطة حرجة. الربط بالذكاء الاصطناعي: جداول معدّل التعلّم (8.23).

مثال (5-2.23): حجم الدفعة المعطيات: دفعة بحجم B. المطلوب: أثر التباين. الحل: الخطوة 1: التباين يتناقص $\propto 1/B$ لكن التكلفة تتضاعف. النتيجة: مفاضلة حسابية. الربط بالذكاء الاصطناعي: اختيار batch size.

مثال (6-2.23): العصر (epoch) المعطيات: n عيّنة، دفعة 1. المطلوب: التكرارات لكلّ عصر. الحل: الخطوة 1: n تكراراً لكلّ عصر. النتيجة: تعريف مصطلح. الربط بالذكاء الاصطناعي: تنظيم حلقة التدريب.

مثال (7-2.23): الخلط العشوائي المعطيات: بدون خلط. المطلوب: المشكلة. الحل: الخطوة 1: ارتباط بين العيّنات يحيّز التسلسل. النتيجة: نخلط العيّنات كلّ عصر. الربط بالذكاء الاصطناعي: shuffle في DataLoader.

مثال (8-2.23): تكلفة التكرار المعطيات: تدرّج كامل مقابل عشوائي. المطلوب: المقارنة. الحل: الخطوة 1: العشوائي أرخص بعامل n. النتيجة: سبب شيوع SGD. الربط بالذكاء الاصطناعي: تدريب النماذج الضخمة.

مثال (9-2.23): التقارب للمحدّب المعطيات: f محدّبة سلسة. المطلوب: المعدّل. الحل: الخطوة 1: $O(1/\sqrt{K})$ في نُرم التدرّج (أو $O(1/K)$ بالمتوسط المرجّح). النتيجة: أبطأ من الدفعي. الربط بالذكاء الاصطناعي: ميزانية التدريب.

مثال (10-2.23): الضوضاء تهرّب من السرج المعطيات: شبكة بسروج. المطلوب: الفائدة. الحل: الخطوة 1: الضوضاء تدفع خارج نقاط السرج الملتفّة. النتيجة: SGD ينجح في غير المحدّب. الربط بالذكاء الاصطناعي: تفسير نجاح التعلّم العميق.

مثال (11-2.23): الخطوة الثابتة المعطيات: η ثابت كبير. المطلوب: السلوك. الحل: الخطوة 1: يتذبذب حول الحلّ ولا يستقرّ. النتيجة: «جوار» بعرض يتناسب مع $\eta\sigma^2$. الربط بالذكاء الاصطناعي: لماذا نضبط معدّل التعلّم.

مثال (12-2.23): المتوسط المرجّح المعطيات: نأخذ متوسط المسار. المطلوب: الفائدة. الحل: الخطوة 1: يخفض أثر الضوضاء (Polyak averaging). النتيجة: تقدير أفضل. الربط بالذكاء الاصطناعي: model averaging/EMA.

مثال (13-2.23): SGD والانحدار الخطّي المعطيات: $f_i = (a_i^\top x - b_i)^2$. المطلوب: التحديث. الحل: الخطوة 1: $\hat{g} = 2(a_i^\top x - b_i)a_i$. النتيجة: تحديث بعيّنة واحدة. الربط بالذكاء الاصطناعي: تدريب انحدار واسع النطاق.

مثال (14-2.23): التدرّج الصاخب والدقة المعطيات: نريد دقّة عالية. المطلوب: المشكلة. الحل: الخطوة 1: الضوضاء تمنع الدقّة بأيّ η ثابت. النتيجة: نلجأ لتقليل التباين (7.23) أو دفعات كبيرة. الربط بالذكاء الاصطناعي: متى ننتقل لـ L-BFGS؟

مثال (15-2.23): شروط التوقّف المعطيات: تدريب شبكة. المطلوب: المعيار. الحل: الخطوة 1: نراقب خسارة التحقّق لا التدرّج (صاخب). النتيجة: توقّف مبكّر عملي. الربط بالذكاء الاصطناعي: early stopping.

أخطاء شائعة

- توقّع تقارب دقيق بخطوة ثابتة.
- نسيان خلط العيّنات كلّ عصر.
- استخدام η كبير فيظنّ المرء أنّ النموذج «لا يتعلّم».
- الخلط بين معدّل تقارب الدفعي والعشوائي.

$$v_{k+1} = \beta\, v_k + \nabla f(x_k), \qquad x_{k+1} = x_k - \eta\, v_{k+1}, \qquad \beta \in [0, 1) \tag{2.23}$$

ويُقرأ كتراكم أُسّي للتدرّجات الماضية بوزن متضائل.

جدول الرموز

الرمز	المعنى
v_k	سرعة/زخم متراكم
β	معامل الاحتفاظ (عادة 0.9)
η	معدّل التعلّم
تراكم أُسّي	$v \propto \sum \beta^j \nabla f$

الرسم

<figure> الشكل<figcaption> 2.23: الزخم يخفّف التعرّج في الأودية الضيّقة فيتقدّم المسار بسلاسة



شكل ٢٠٢٣: *
الزخم الثقيل: كرة تتدحرج في واد

أكبر.</figcaption> </figure>

البرهان (مخطّط)

بحلّ التكرار: $v_{k+1} = \sum_{j=0}^{k} \beta^j \nabla f(x_{k-j})$. في وادٍ ضيّق (من 5.20) تتعاكس مركّبات التعرّج فتلغي نفسها، فيما تتراكم مركّبة التقدّم $\Rightarrow$ تضاؤل أسرع. ■

خمسة عشر مثالاً محلولاً

مثال (3.23-1): التحديث الأول المعطيات: $v_0 = 0$، $\beta = 0.9$، $g = 1$، $\eta = 0.1$. المطلوب: x_1, v_1. الحل: الخطوة 1: $v_1 = 0.9(0) + 1 = 1$. الخطوة 2: $x_1 = x_0 - 0.1(1) = x_0 - 0.1$. النتيجة: $v_1 = 1$. الربط بالذكاء الاصطناعي: بدء التدريب بالزخم.

مثال (3.23-2): التراكم المعطيات: تدرّج ثابت g لثلاث خطوات. المطلوب: v_3. الحل: الخطوة 1: $v_1 = g$، $v_2 = (1+\beta)g$، $v_3 = (1+\beta+\beta^2)g$. الخطوة 2: بـ $\beta = 0.9$: $2.71g$. النتيجة: تضخّم تدريجي. الربط بالذكاء الاصطناعي: تسريع في الاتجاهات الثابتة.

مثال (3.23-3): إلغاء التعرّج المعطيات: تدرّج يتبادل الإشارة. المطلوب: السلوك. الحل: الخطوة 1: المركّبات

المتعاكسة تلغي جزئيًّا. النتيجة: مسار أنعم. الربط بالذكاء الاصطناعي: أودية الخسارة الضيّقة.

مثال (23.3.4): اختيار المعطيات: $\beta = 0.9$ مقابل $\beta = 0.99$. المطلوب: الفرق. الحل: الخطوة 1: الأكبر يعني ذاكرة أطول وتضخّماً أكبر. النتيجة: 9.0 شائع في الرؤية. الربط بالذكاء الاصطناعي: ضبط هايبرمعاملات.

مثال (23.3.5): السرعة القصوى المعطيات: تدرّج ثابت، $1 \to \beta$. المطلوب: الحدّ. الحل: الخطوة 1: $g/(1-\beta) \Rightarrow v \to g/(1-\beta)$ تضخّم بعامل $1/(1-\beta)$. النتيجة: نخفض η تبعاً لذلك. الربط بالذكاء الاصطناعي: موازنة η و β.

مثال (23.3.6): الزخم في الوادي الضيّق المعطيات: $\kappa = 100$ (من 5.20). المطلوب: التحسّن. الحل: الخطوة 1: الزخم يقلّل عدد التذبذبات. النتيجة: تقارب أسرع من SGD الخام. الربط بالذكاء الاصطناعي: تدريب الشبكات العميقة.

مثال (23.3.7): حدس الكرة المعطيات: كرة تتدحرج. المطلوب: التفسير. الحل: الخطوة 1: الزخم = كتلة؛ الاحتكاك = $(1-\beta)$. النتيجة: استعارة فيزيائية. الربط بالذكاء الاصطناعي: فهم حدسي للمحسّنات.

مثال (23.3.8): الزخم مع الضوضاء المعطيات: SGD صاخب + زخم. المطلوب: الأثر. الحل: الخطوة 1: يوسّط الضوضاء جزئيًّا (تراكم أُسّي). النتيجة: تحديث أنعم. الربط بالذكاء الاصطناعي: لماذا الزخم شائع مع SGD.

مثال (23.3.9): مقارنة بالدفعي المعطيات: محدّب سلس. المطلوب: التحسّن. الحل: الخطوة 1: يقارب تسريع نيستروف في بعض الحالات. النتيجة: تحسين دون تكلفة. الربط بالذكاء الاصطناعي: مكسب مجّاني تقريباً.

مثال (23.3.10): متى يضرّ الزخم المعطيات: مشهد شديد الوعورة. المطلوب: الخطر. الحل: الخطوة 1: الزخم قد يتجاوز الأصغريات الضحلة. النتيجة: نخفض β أو نعيد التشغيل. الربط بالذكاء الاصطناعي: تصحيح سلوك التدريب.

مثال (23.3.11): العلاقة بالمعدّل الفعّال المعطيات: η و β. المطلوب: الخطوة الفعّالة. الحل: الخطوة 1: تقريباً في الاتجاه الثابت $\eta/(1-\beta)$. النتيجة: موازنة المعاملات. الربط بالذكاء الاصطناعي: نقل إعدادات بين المحسّنات.

مثال (23.3.12): تهيئة v_0 المعطيات: بداية التدريب. المطلوب: القيمة. الحل: الخطوة 1: $v_0 = 0$ فتصير الخطوات الأولى صغيرة. النتيجة: حاجة لـ warmup (8.23). الربط بالذكاء الاصطناعي: تسخين معدّل التعلّم.

مثال (23.3.13): الزخم والتنظيم المعطيات: decay weight مع الزخم. المطلوب: الملاحظة. الحل: الخطوة 1: يجب أن يُطبق الاضمحلال على x لا داخل التدرّج (AdamW، 6.23). النتيجة: فرق دقيق ومهمّ. الربط بالذكاء الاصطناعي: AdamW مقابل Adam+L2.

مثال (23.3.14): زخم متغيّر المعطيات: نغيّر β مع الزمن. المطلوب: الفائدة. الحل: الخطوة 1: نبدأ صغيراً ثمّ نرفعه (جدولة الزخم). النتيجة: استقرار ثمّ تسريع. الربط بالذكاء الاصطناعي: جداول حديثة.

مثال (23.3.15): التشخيص المعطيات: الخسارة تتذبذب بعنف. المطلوب: الاحتمالات. الحل: الخطوة 1: η كبير أو β كبير. النتيجة: نخفض أحدهما. الربط بالذكاء الاصطناعي: تصحيح أخطاء التدريب.

أخطاء شائعة

- رفع β دون خفض η.
- نسيان أنّ الزخم يضخّم الخطوة الفعّالة.
- تطبيق decay weight داخل التدرّج (خطأ Adam).
- استخدام زخم مع تدرّجات متضاربة جدّاً بلا حذر.

الفرق الجوهري: نقيس التدرّج في **نقطة مستبقة**:

$$y_k = x_k + \beta\,(x_k - x_{k-1}), \qquad x_{k+1} = y_k - \eta\,\nabla f(y_k) \tag{3.23}$$

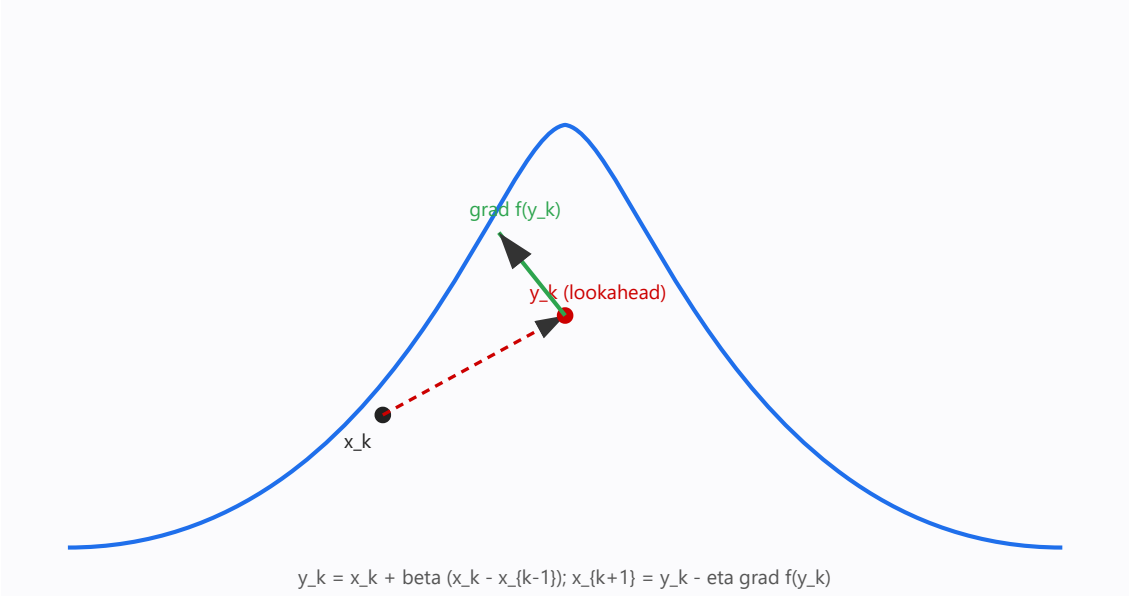
فيحصل المعدّل $O(1/k^2)$ للمحدّب السلس مقابل $O(1/k)$.

جدول الرموز

الرمز	المعنى
y_k	نقطة الاستباق
$\beta(x_k - x_{k-1})$	قفزة الزخم
تصحيح	يقيس التدرّج حيث سنكون

الرسم

<figure> الشكل<figcaption> 3.23: نستبق بالزخم ثمّ نقيّم التدرّج هناك، فنصحّح قبل أن نتجاوز.</figcaption>



شكل ٣.٢٣: *
تسريع نيستروف: القياس في نقطة مستبقة

</figure>

البرهان (مخطّط)

بمبرهنة «تسلسل التقدير» (كما في 8.22) مع $t_k \approx k/2$: يبقى حدّ سفلي مكعّب يتقلّص بعامل $(1 - 1/t_k)$، فيتراكم الخطأ كـ $O(1/k^2)$. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.23): حساب الاستباق المعطيات: $x_k = 5$، $x_{k-1} = 4$، $\beta = 0.9$. المطلوب: y_k. الحل: الخطوة 1: $y = 5 + 0.9(1) = 5.9$. النتيجة: $y_k = 5.9$. الربط بالذكاء الاصطناعي: صيغة جاهزة للتنفيذ.

مثال (2-4.23): الفرق عن الزخم الثقيل المعطيات: الزخم يقيس في x_k؛ نيستروف في y_k. المطلوب: الأثر.

الحل: الخطوة 1: نيستروف «يرى» إلى أين يتجه فيصحّح مبكراً. النتيجة: استقرار أفضل. الربط بالذكاء الاصطناعي: تفضيل نيستروف في الرؤية.

مثال (23.4-3): المعدّل المعطيات: محدّب سلس. المطلوب: المقارنة. الحل: الخطوة 1: $O(1/k^2)$ مقابل $O(1/k)$ لهبوط التدرّج. النتيجة: تسريع نظري مضمون. الربط بالذكاء الاصطناعي: ميزانية التكرارات.

مثال (23.4-4): صيغة بديلة المعطيات: نريد صيغة بمتراكم واحد. المطلوب: التحويل. الحل: الخطوة 1: $v_{k+1} = \beta v_k + \nabla f(y_k)$، $x_{k+1} = x_k - \eta(\beta v_{k+1} + \nabla f(y_k))$. النتيجة: تكافؤ. الربط بالذكاء الاصطناعي: تنفيذات المكتبات.

مثال (23.4-5): التحدّب القوي المعطيات: نعرف μ, L. المطلوب: المعدّل. الحل: الخطوة 1: خطّي بعامل $1 - \sqrt{\mu/L}$ (أسرع من $1 - \mu/L$ في 7.20). النتيجة: تحسين مربّع الجذر. الربط بالذكاء الاصطناعي: ضبط بمعرفة الانحناء.

مثال (23.4-6): إعادة التشغيل المعطيات: تذبذب متزايد. المطلوب: المعالجة. الحل: الخطوة 1: نعيد $t_k = 1$/نصفّر الزخم دورياً. النتيجة: تقارب أنعم. الربط بالذكاء الاصطناعي: تقنيات حديثة.

مثال (23.4-7): مع الضوضاء المعطيات: SGD صاخب. المطلوب: التحذير. الحل: الخطوة 1: الاستباق قد يضخّم الضوضاء عند β كبير. النتيجة: نضبط β بحذر. الربط بالذكاء الاصطناعي: إعدادات التدريب العميق.

مثال (23.4-8): تطبيق في الرؤية المعطيات: تدريب ResNet. المطلوب: الملاحظة. الحل: الخطوة 1: SGD + نيستروف هو المعيار الذهبي في الرؤية. النتيجة: تعميم أفضل من المحسّنات التكيّفية أحياناً. الربط بالذكاء الاصطناعي: ممارسة مجرّبة.

مثال (23.4-9): متى لا يفيد المعطيات: غير محدّب عميق بضوضاء. المطلوب: الحكم. الحل: الخطوة 1: المكاسب النظرية قد لا تتحقّق. النتيجة: نجرّب empirically. الربط بالذكاء الاصطناعي: تقييم عملي.

مثال (23.4-10): العلاقة بـ FISTA المعطيات: 8.22 استخدمنا نفس الفكرة. المطلوب: الرابط. الحل: الخطوة 1: FISTA هو نيستروف مع خطوة قريبة. النتيجة: توحيد المفاهيم. الربط بالذكاء الاصطناعي: وحدة النظرية.

مثال (23.4-11): حساب t_k المعطيات: $t_0 = 1$. المطلوب: التسلسل. الحل: الخطوة 1: $t_{k+1} = \frac{1+\sqrt{1+4t_k^2}}{2} \Rightarrow$ ينمو $\approx k/2$. النتيجة: جدولة الزخم. الربط بالذكاء الاصطناعي: تنفيذ دقيق.

مثال (23.4-12): مقارنة عددية المعطيات: $k = 100$، $\kappa = 100$. المطلوب: الفرق. الحل: الخطوة 1: الهبوط يحتاج $\kappa \ln(1/\epsilon)$، نيستروف $\sqrt{\kappa}\ln(1/\epsilon)$. النتيجة: أسرع بعامل 10 هنا. الربط بالذكاء الاصطناعي: مكسب ملموس.

مثال (23.4-13): التدرّج في y المعطيات: تكلفة إضافية؟ المطلوب: الحكم. الحل: الخطوة 1: نفس عدد تقييمات التدرّج (نعيد استخدامه). النتيجة: بلا تكلفة إضافية تقريباً. الربط بالذكاء الاصطناعي: كفاءة الحساب.

مثال (23.4-14): الاستقرار المعطيات: η كبير مع نيستروف. المطلوب: الخطر. الحل: الخطوة 1: الاستباق قد يسبّب تجاوزاً أكبر. النتيجة: نخفض η أو نستخدم warmup. الربط بالذكاء الاصطناعي: تصحيح التدريب.

مثال (23.4-15): الخلاصة المعطيات: متى نختاره؟ المطلوب: الحكم. الحل: الخطوة 1: للمحدّب/الرؤية مع SGD؛ ممتاز. النتيجة: دليل اختيار. الربط بالذكاء الاصطناعي: هندسة المحسّنات.

أخطاء شائعة

- الخلط بين نيستروف والزخم الثقيل (مختلفان في موضع التقييم).
- استخدام β كبير مع ضوضاء عالية.
- نسيان أنّ المكاسب النظرية تفترض التحدّب/السلاسة.
- تطبيق تسريع دون إعادة تشغيل عند التذبذب.

AdaGrad يراكم مربّعات التدرّجات فيقسّم الخطوة على جذرها:

$$G_k = \sum_{t=1}^{k} g_t \odot g_t, \qquad x_{k+1} = x_k - \frac{\eta}{\sqrt{G_k + \epsilon}} \odot g_k \tag{4.23}$$

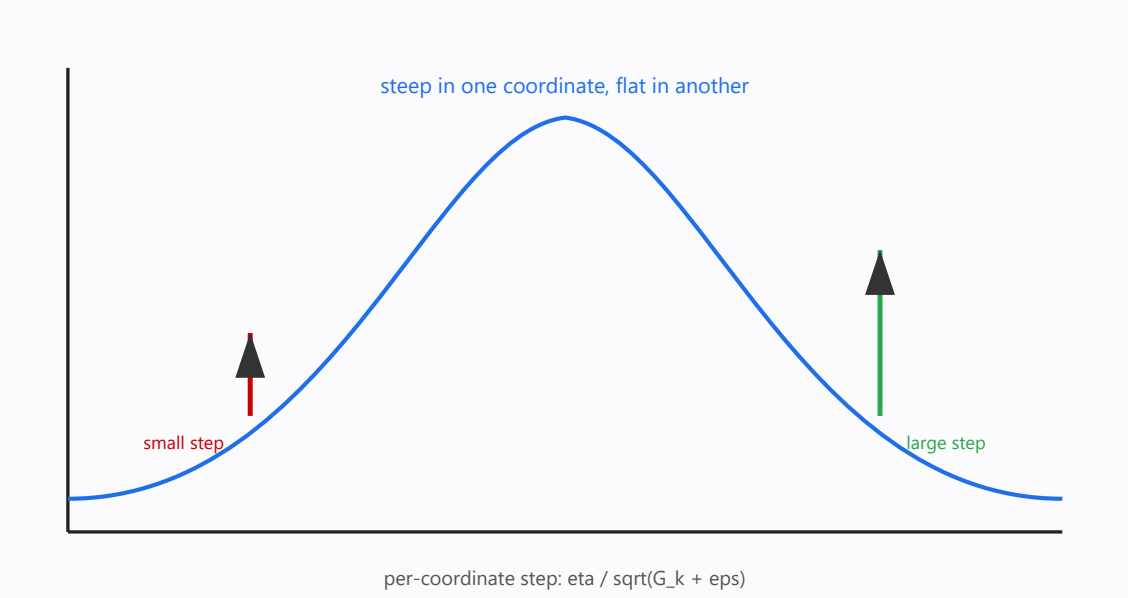
و **RMSProp** يستبدل المجموع بمتوسّط متحرّك أُسّي: $v_k = \beta v_{k-1} + (1-\beta) g_k \odot g_k$.

جدول الرموز

الرمز	المعنى
$\odot$	الضرب الإحداثي
G_k	تراكم المربّعات (AdaGrad)
v_k	متوسّط متحرّك (RMSProp)
ϵ	ثابت استقرار ($\sim 10^{-8}$)

الرسم

<figure> الشكل<figcaption> 4.23: لكلّ إحداثي خطوته، فتتكيّف مع تكرار التدرّج والخداره.</figcaption>



شكل ٤.٢٣: *
الطرق التكيفية AdaGrad و RMSProp

</figure>

البرهان (مخطّط)

AdaGrad يكافئ استخدام مقياس $\operatorname{diag}(G_k)^{-1/2}$، للمحدّب يعطي حدّ ندم (regret) $O(\sqrt{K})$، أي يتكيّف مع هندسة المشكلة. RMSProp يضيف نسياناً أُسّيّاً فلا يتضخّم المقام مع الزمن. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.23): تحديث AdaGrad المعطيات: $g = 2$، $G = 4$، $\eta = 0.1$، $\epsilon = 10^{-8}$. المطلوب: الخطوة. الحل: الخطوة 1: $\frac{0.1}{\sqrt{4}}(2) = 0.1$. النتيجة: خطوة 1.0. الربط بالذكاء الاصطناعي: تكييف الإحداثيات.

مثال (٢٣.٥-2): إحداثي نادر المعطيات: إحداثي يظهر نادراً بتدرّج كبير. المطلوب: السلوك. الحل: الخطوة 1: مقامه صغير ⇒ خطوة كبيرة عندما يظهر. النتيجة: مناسب للميزات النادرة. الربط بالذكاء الاصطناعي: تضمينات الكلمات النادرة.

مثال (٢٣.٥-3): إحداثي متكرّر المعطيات: إحداثي متكرّر التدرّج. المطلوب: السلوك. الحل: الخطوة 1: مقامه يكبر ⇒ خطوة تتضاءل. النتيجة: استقرار تلقائي. الربط بالذكاء الاصطناعي: معاملات متذبذبة.

مثال (٢٣.٥-4): مشكلة تضخّم المقام المعطيات: AdaGrad لزمن طويل. المطلوب: المشكلة. الحل: الخطوة 1: G_k يتراكم بلا توقّف ⇒ الخطوة 0 $\to$. النتيجة: توقّف مبكر عن التعلّم. الربط بالذكاء الاصطناعي: سبب ظهور RMSProp/Adam.

مثال (٢٣.٥-5): RMSProp يحلّ المشكلة المعطيات: نستخدم متوسّطاً متحرّكاً. المطلوب: الفرق. الحل: الخطوة 1: المقام ينسي القديم فلا يتضخّم بلا حدّ. النتيجة: تعلّم مستمرّ. الربط بالذكاء الاصطناعي: تدريب طويل.

مثال (٢٣.٥-6): اختيار β المعطيات: RMSProp بـ $\beta = 0.99$. المطلوب: المعنى. الحل: الخطوة 1: ذاكرة أطول لتقدير المقياس. النتيجة: تقدير أنعم. الربط بالذكاء الاصطناعي: إعدادات نموذجية.

مثال (٢٣.٥-7): دور ϵ المعطيات: $\epsilon = 0$. المطلوب: الخطر. الحل: الخطوة 1: قسمة على صفر في البداية. النتيجة: نضيف ϵ صغيراً. الربط بالذكاء الاصطناعي: استقرار عددي.

مثال (٢٣.٥-8): التكييف القطري المعطيات: نقيّد المقياس للمربّعات فقط. المطلوب: الحدّ. الحل: الخطوة 1: لا يراعي الارتباطات بين الإحداثيات. النتيجة: أرخص من الهِسّية الكاملة. الربط بالذكاء الاصطناعي: تكييف رخيص.

مثال (٢٣.٥-9): مقارنة بالهِسّية المعطيات: نيوتن يستخدم H^{-1}. المطلوب: العلاقة. الحل: الخطوة 1: الطرق التكيّفية تقريب قطري لـ H^{-1} (من ٢٣.٥-8). النتيجة: تفسير نظري. الربط بالذكاء الاصطناعي: لماذا تنجح؟

مثال (٢٣.٥-10): حدّ الندم المعطيات: إطار الاتصال بالإنترنت .(online) المطلوب: النتيجة. الحل: الخطوة 1: AdaGrad يحقّق ندماً $O(\sqrt{K})$. النتيجة: ضمان نظري. الربط بالذكاء الاصطناعي: تعلّم متصل/متدفّق.

مثال (٢٣.٥-11): التطبيقات على النصوص المعطيات: نموذج لغوي بتضمينات. المطلوب: الملاحظة. الحل: الخطوة 1: AdaGrad فعّال للميزات المتناثرة. النتيجة: سبب شيوعه في البرمجة اللغوية. الربط بالذكاء الاصطناعي: تدريب نماذج اللغة.

مثال (٢٣.٥-12): التدهور في التدريب الطويل المعطيات: تدريب آلاف العصور. المطلوب: للماذا؟ الحل: الخطوة 1: AdaGrad يجمّد التعلّم؛ RMSProp/Adam أفضل. النتيجة: دليل اختيار. الربط بالذكاء الاصطناعي: هندسة المحسّنات.

مثال (٢٣.٥-13): التدرّجات المتفرّقة المعطيات: تدرّج أصفار كثيرة. المطلوب: الفائدة. الحل: الخطوة 1: التكييف القطري يتعامل مع التفاوت بين الإحداثيات. النتيجة: تحديث متوازن. الربط بالذكاء الاصطناعي: نماذج متناثرة/مدخلات متفرّقة.

مثال (٢٣.٥-14): الضبط المعطيات: η في RMSProp. المطلوب: النطاق. الحل: الخطوة 1: عادة 10^{-3} إلى 10^{-2} حسب النموذج. النتيجة: نقطة بداية. الربط بالذكاء الاصطناعي: إعدادات افتراضية.

مثال (٢٣.٥-15): الانتقال لـ Adam المعطيات: نريد زخماً مع التكييف. المطلوب: الخطوة التالية. الحل: الخطوة 1: Adam يجمع الزخم مع RMSProp (٢٣.٦). النتيجة: المعيار الحديث. الربط بالذكاء الاصطناعي: تطوّر المحسّنات.

أخطاء شائعة

- نسيان ϵ فتحدث قسمة على صفر.
- اعتبار AdaGrad مناسباً للتدريب الطويل جدّاً.
- الخلط بين G_k (مجموع) و v_k (متوسّط متحرّك).

- توقّع أن التكييف القطري يعالج الارتباطات (لا يفعل).

$$m_k = \beta_1 m_{k-1} + (1-\beta_1) g_k, \quad v_k = \beta_2 v_{k-1} + (1-\beta_2) g_k^2, \quad x_{k+1} = x_k - \eta \frac{\hat{m}_k}{\sqrt{\hat{v}_k} + \epsilon} \tag{5.23}$$

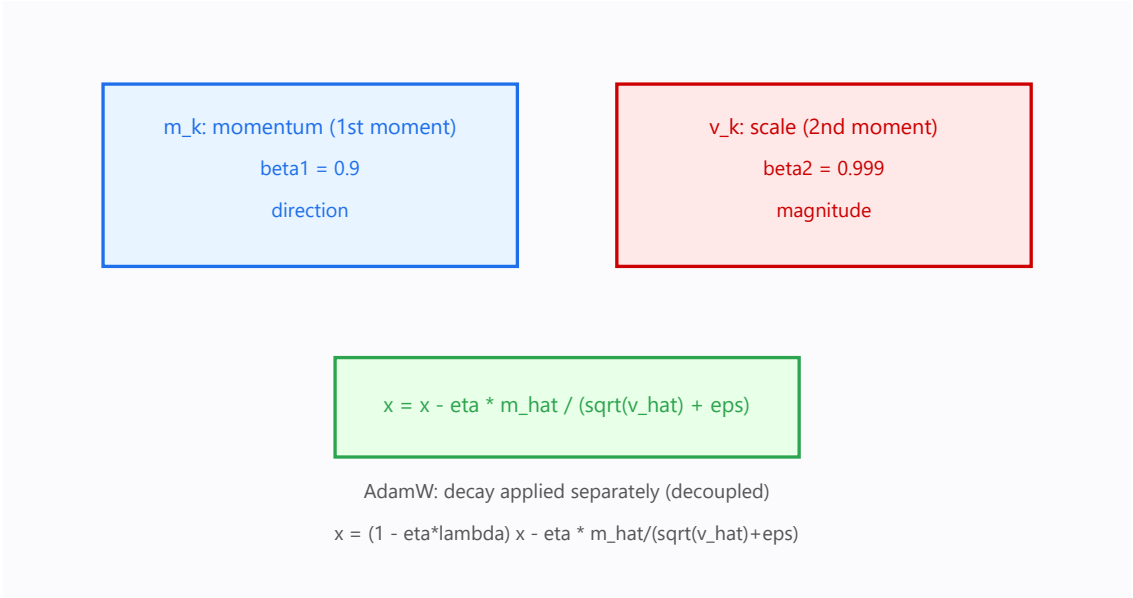
بتصحيح الانحياز $\hat{m}_k = m_k/(1-\beta_1^k)$ و $\hat{v}_k = v_k/(1-\beta_2^k)$. و **AdamW** يفصل decay weight عن التدرّج.

جدول الرموز

الرمز	المعنى
m_k	اللحظة الأولى (الزخم)
v_k	اللحظة الثانية (المقياس)
$\hat{m}, \hat{v}$	مصحّحة الانحياز
β_1, β_2	عادة 0.9 و 0.999

الرسم

<figure> الشكل<figcaption> 5.23: Adam يجمع الزخم والتكييف القطري؛ AdamW يفصل اضمحلال



شكل ٥.٢٣: *
Adam و AdamW

الوزن.</figcaption> </figure>

البرهان (مخطّط)

بما أن $m_0 = v_0 = 0$، فالتقديران منحازان نحو الصفر؛ القسمة على $(1-\beta^k)$ تصحّح الانحياز فتستقيم الخطوات الأولى. AdamW يطبّق $x \leftarrow (1-\eta\lambda)x$ منفصلاً عن تحديث التدرّج، فيفصل مقياس التنظيم عن مقياس التكييف (عكس L2 داخل التدرّج). ■

خمسة عشر مثالاً محلولاً

مثال (23.6.1): التحديث الأول المعطيات: $g = 1$، $\beta_1 = 0.9$، $\beta_2 = 0.999$، $\eta = 0.001$. المطلوب: $\hat{m}_1, \hat{v}_1$. الحل: الخطوة 1: $m_1 = 0.1$، $v_1 = 0.001$. الخطوة 2: $\hat{m}_1 = 0.1/0.1 = 1$، $\hat{v}_1 = 0.001/0.001 = 1$. النتيجة: النسبة 1 $\Rightarrow$ الخطوة $-\eta$. الربط بالذكاء الاصطناعي: بداية صحيحة بلا انكماش.

مثال (23.6.2): أهمّية التصحيح المعطيات: بلا تصحيح. المطلوب: المشكلة. الحل: الخطوة 1: $m_1 = 0.1g \Rightarrow$ خطوات أولى صغيرة جدّاً. النتيجة: بطء البداية. الربط بالذكاء الاصطناعي: أهمّية التصحيح/warmup.

مثال (23.6.3): نسبة الإشارة إلى الضجيج المعطيات: $\hat{m}/\sqrt{\hat{v}}$. المطلوب: التفسير. الحل: الخطوة 1: تشبه نسبة «المتوسط/الانحراف» $\Rightarrow$ تحديث بحدود ± 1 تقريباً. النتيجة: حجم خطوة مستقرّ. الربط بالذكاء الاصطناعي: ثبات التدريب.

مثال (23.6.4): β_2 كبير المعطيات: 0.999. المطلوب: السبب. الحل: الخطوة 1: تقدير مستقرّ للمقياس بذاكرة طويلة. النتيجة: تكييف أنعم. الربط بالذكاء الاصطناعي: إعدادات قياسية.

مثال (23.6.5): AdamW مقابل Adam+L2 المعطيات: نريد تنظيماً. المطلوب: الفرق. الحل: الخطوة 1: Adam+L2 يقسّم التنظيم على المقياس فيُضعفه للمعاملات الكبيرة. الخطوة 2: AdamW يطبّقه مباشرة $\Rightarrow$ تنظيم متسق. النتيجة: AdamW أدقّ. الربط بالذكاء الاصطناعي: تدريب المحوّلات.

مثال (23.6.6): إعدادات نموذجية المعطيات: تدريب محوّل. المطلوب: القيم. الحل: الخطوة 1: $\eta = 10^{-3}$ أو أقلّ، $\beta_1 = 0.9$، $\beta_2 = 0.999$، $\epsilon = 10^{-8}$. النتيجة: نقطة بداية. الربط بالذكاء الاصطناعي: ممارسة شائعة.

مثال (23.6.7): لماذا Adam يناسب النماذج الضخمة المعطيات: مليارات المعاملات. المطلوب: السبب. الحل: الخطوة 1: التكييف القطري يغني عن ضبط دقيق لكلّ إحداثي. النتيجة: تدريب مستقرّ واسع النطاق. الربط بالذكاء الاصطناعي: LLMs.

مثال (23.6.8): التعميم المعطيات: مقارنة SGD مقابل Adam. المطلوب: الملاحظة. الحل: الخطوة 1: الزخم+SGD يعمّم أفضل أحياناً في الرؤية. النتيجة: لا محسّن عالمي. الربط بالذكاء الاصطناعي: تجربة المقارنة.

مثال (23.6.9): مشكلة التقارب المعطيات: حالات لا يتقارب فيها Adam. المطلوب: السبب. الحل: الخطوة 1: الذاكرة الأُسّية قد تسبّب عدم استقرار (معروف نظريّاً). النتيجة: بدائل جدولة/AMSGrad. الربط بالذكاء الاصطناعي: تحسينات حديثة.

مثال (23.6.10): ϵ والاستقرار المعطيات: ϵ كبير جدّاً. المطلوب: الأثر. الحل: الخطوة 1: يضعف التكييف (يصير كـ SGD). النتيجة: نبقيه صغيراً. الربط بالذكاء الاصطناعي: إعداد دقيق.

مثال (23.6.11): التدرّجات المتفرّقة المعطيات: تدرّج متفرّق (embedding). المطلوب: الملاحظة. الحل: الخطوة 1: Adam يتعامل جيداً مع التفاوت في تواتر التحديث. النتيجة: مناسب للتضمينات. الربط بالذكاء الاصطناعي: نماذج التوصية/اللغة.

مثال (23.6.12): الضبط الدقيق المعطيات: fine-tuning نموذج مُدرَّب مسبقاً. المطلوب: الإعداد. الحل: الخطوة 1: η صغير (10^{-5}) مع AdamW و warmup قصير. النتيجة: تجنّب تخريب الأوزان. الربط بالذكاء الاصطناعي: نقل التعلّم.

مثال (23.6.13): قصّ التدرّج مع Adam المعطيات: انفجار التدرّجات. المطلوب: المعالجة. الحل: الخطوة 1: نقصّ نُرم التدرّج قبل التحديث (من 6.21). النتيجة: استقرار إضافي. الربط بالذكاء الاصطناعي: تدريب المحوّلات/RNN.

مثال (23.6.14): الدقة المختلطة المعطيات: تدريب بـ fp16. المطلوب: الحذر. الحل: الخطوة 1: v_k قد يصغر فيفقد الدقّة $\Rightarrow$ نستخدم weights master بـ fp32. النتيجة: تدريب آمن بدقّة مختلطة. الربط بالذكاء الاصطناعي: تسريع التدريب.

مثال (23.6-15): ماذا نختار؟ المعطيات: مهمة جديدة. المطلوب: التوصية. الحل: الخطوة 1: AdamW للنماذج الضخمة/اللغة؛ نيستروف+SGD للرؤية. النتيجة: دليل عملي. الربط بالذكاء الاصطناعي: قرارات هندسية.

أخطاء شائعة

- نسيان تصحيح الانحياز (خطوات أولى خاطئة).
- استخدام Adam مع L2 داخلي بدل AdamW.
- رفع ϵ فيفقد التكييف معناه.
- توقّع أنّ Adam أفضل دائماً (ليس في كلّ المهمّات).

SVRG يستخدم مرساة (snapshot) $\tilde{x}$ وتقديراً مصحّحاً:

$$\hat{g}_k = \nabla f_{i_k}(x_k) - \nabla f_{i_k}(\tilde{x}) + \nabla f(\tilde{x}), \qquad \mathbb{E}[\hat{g}_k] = \nabla f(x_k), \quad \text{Var} \to 0 \tag{6.23}$$

فيصير ممكناً استخدام **خطوة ثابتة** مع تقارب خطّي للمحدّب القوي.

جدول الرموز

الرمز	المعنى
$\tilde{x}$	نقطة المرساة
$\nabla f(\tilde{x})$	التدرّج الكامل عند المرساة
المصحّح	يلغي التباين تدريجياً
خطوة ثابتة	بفضل تضاؤل التباين

الرسم

<figure> الشكل 6.23: بطرح التدرّج عند المرساة يتبقّى تباين يتضاءل مع اقتراب x_k من $\tilde{x}$. </figcaption></figure>

البرهان (مخطّط)

$\mathbb{E}[\hat{g}_k] = \nabla f(x_k)$ مباشرة. والتباين $\mathbb{E}\|\hat{g}_k - \nabla f(x_k)\|^2 \le C\,\mathbb{E}\|x_k - \tilde{x}\|^2$ بسلاسة f؛ فإذا تحدّثنا المرساة دورياً يبقى التباين صغيراً، فتتحقّق نتيجة تقارب خطّي بخطوة ثابتة. ■

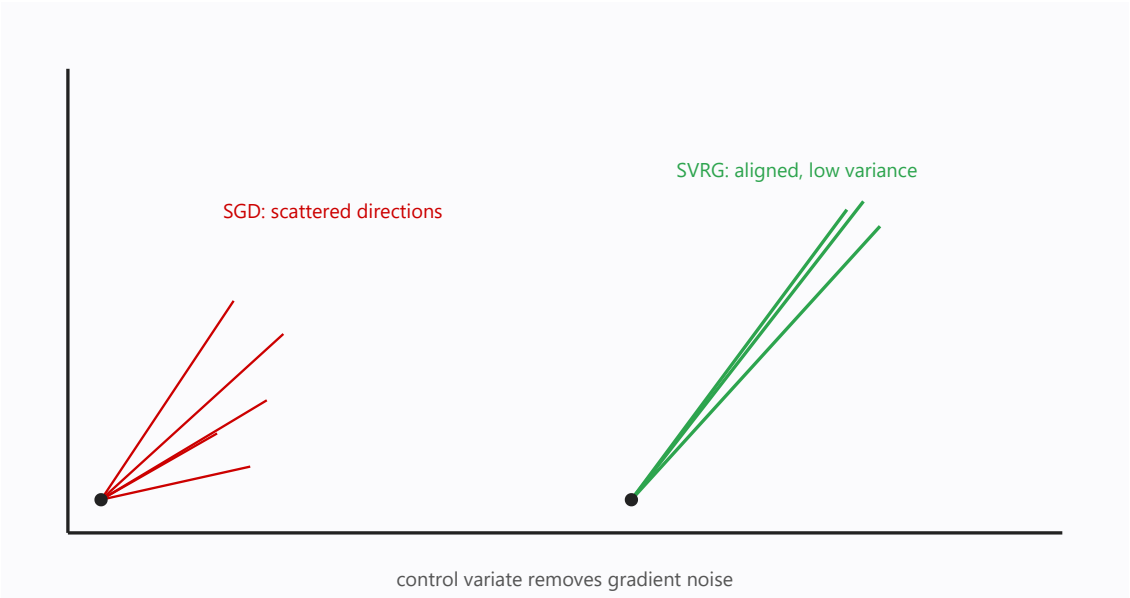
خمسة عشر مثالاً محلولاً

مثال (23.7-1): صيغة SVRG المعطيات: x_k، $\tilde{x}$، فهرس i. المطلوب: $\hat{g}_k$. الحل: الخطوة 1: $\nabla f_i(x_k) - \nabla f_i(\tilde{x}) + \nabla f(\tilde{x})$. النتيجة: التقدير المصحّح. الربط بالذكاء الاصطناعي: خوارزميات متقدّمة.

مثال (23.7-2): عدم التحيّز المعطيات: التقدير أعلاه. المطلوب: التوقّع. الحل: الخطوة 1: $\mathbb{E}[\nabla f_i(x_k)] - \mathbb{E}[\nabla f_i(\tilde{x})] + \nabla f(\tilde{x}) = \nabla f(x_k)$. النتيجة: غير متحيّز. الربط بالذكاء الاصطناعي: شرط صحّة أساسي.

مثال (23.7-3): تضاؤل التباين المعطيات: $x_k \to \tilde{x}$. المطلوب: التباين. الحل: الخطوة 1: الفرق يتضاءل $\Rightarrow$ التباين $\to 0$. النتيجة: دقّة قريبة من الدفعي. الربط بالذكاء الاصطناعي: دقّة عالية بتكلفة عشوائية.

مثال (23.7-4): تحديث المرساة المعطيات: كلّ m تكرار. المطلوب: الإجراء. الحل: الخطوة 1: نحدّث $\tilde{x}$ (متوسط أو آخر نقطة) ونحسب التدرّج الكامل. النتيجة: حلقتان داخلية/خارجية. الربط بالذكاء الاصطناعي: بنية الخوارزمية.



شكل ٦.٢٣: *
تقليل التباين SVRG و SAGA

مثال (23.7-5): اختيار m المعطيات: m صغير مقابل كبير. المطلوب: المقايضة. الحل: الخطوة 1: صغير $\Rightarrow$ تحديثات مرساة مكلفة؛ كبير $\Rightarrow$ تباين يعود للتراكم. النتيجة: عادة $m \approx n$ أو $2n$. الربط بالذكاء الاصطناعي: ضبط عملي.

مثال (23.7-6): SAGA المعطيات: نخزّن تدرّجاً لكلّ عيّنة. المطلوب: الفرق. الحل: الخطوة 1: نحتفظ بجدول $\{\nabla f_i(\phi_i)\}$ فلا نحتاج حلقة خارجية. النتيجة: تحديث مستمرّ بذاكرة $O(nd)$. الربط بالذكاء الاصطناعي: مفيد للنماذج الخطّية.

مثال (23.7-7): تكلفة الذاكرة المعطيات: n عيّنة و d بعداً. المطلوب: التكلفة. الحل: الخطوة 1: SAGA يخزّن nd، SVRG يخزّن d فقط. النتيجة: SVRG أخفّ ذاكرة. الربط بالذكاء الاصطناعي: قيود الذاكرة في التدريب.

مثال (23.7-8): التقارب الخطّي المعطيات: محدّب قوي التحدّب. المطلوب: المعدّل. الحل: الخطوة 1: تقارب خطّي كالدفعي لكن بتكلفة تكرار أخفّ. النتيجة: أفضل العالمين. الربط بالذكاء الاصطناعي: تدريب محدّب دقيق.

مثال (23.7-9): متى لا نستخدمه المعطيات: شبكة عميقة ضخمة. المطلوب: الحكم. الحل: الخطوة 1: غير المحدّب وتكلفة المرساة يقلّلان الجدوى. النتيجة: نبقى مع SGD/Adam. الربط بالذكاء الاصطناعي: حدود التطبيق.

مثال (23.7-10): SVRG للانحدار اللوجستي المعطيات: نموذج خطّي محدّب. المطلوب: الفائدة. الحل: الخطوة 1: تقارب خطّي بتكلفة عشوائية. النتيجة: حلّ دقيق وسريع. الربط بالذكاء الاصطناعي: نماذج محدّبة واسعة.

مثال (23.7-11): العلاقة بتقليل التباين العام المعطيات: الفكرة العامّة. المطلوب: المبدأ. الحل: الخطوة 1: استخدم متغيّر تحكّم (control variate) يرتبط بالكمية. النتيجة: تقنية إحصائية عامّة (من 15). الربط بالذكاء الاصطناعي: وصل بالاحتمالات.

مثال (23.7-12): مقارنة بـ SGD المعطيات: نفس الميزانية الحسابية. المطلوب: أيهما؟ الحل: الخطوة 1: SVRG أفضل عند الحاجة لدقّة عالية؛ SGD أبسط وأعمّ. النتيجة: دليل اختيار. الربط بالذكاء الاصطناعي: قرارات المحسّن.

مثال (23.7-13): التباين الأولي المعطيات: بداية التدريب. المطلوب: الملاحظة. الحل: الخطوة 1: التباين كبير $\Rightarrow$ نبدأ بخطوة أصغر أو دفعات أكبر. النتيجة: استقرار البداية. الربط بالذكاء الاصطناعي: warmup.

مثال (23.7-14): التنفيذ المعطيات: نريد تنفيذ SVRG. المطلوب: الخطوات. الحل: الخطوة 1: حلقة خارجية

تحسب التدرّج الكامل؛ داخلية تستخدم المصحّح. النتيجة: بنية واضحة. الربط بالذكاء الاصطناعي: هندسة الخوارزميات.

مثال (7.23-15): الخلاصة النظرية المعطيات: نريد ضماناً. المطلوب: النتيجة. الحل: الخطوة 1: تقليل التباين يستعيد معدّل الدفعي بتكلفة عشوائية. النتيجة: إنجاز نظري مهمّ. الربط بالذكاء الاصطناعي: تصميم محسّنات المستقبل.

أخطاء شائعة

- نسيان تحديث المرساة فلا يتضاءل التباين.
- تخزين SAGA بلا حساب الذاكرة.
- توقّع فائدة في غير المحدّب العميق.
- الخلط بين متغيّر التحكّم والزخم.

الجدولتان الأكثر شيوعاً (بـ T إجمالي التكرارات و k الحالي، و $\eta_{\min}, \eta_{\max}$ حدّين):

$$\eta_k = \eta_{\max} \cdot \frac{k}{T_w} \quad (k < T_w) \ \text{(تسخين)}, \qquad \eta_k = \eta_{\min} + \tfrac{1}{2}(\eta_{\max} - \eta_{\min})\Big(1 + \cos\frac{\pi k}{T}\Big) \quad \text{(جيب التمام)}. \tag{7.23}$$

جدول الرموز

الرمز	المعنى
T	إجمالي التكرارات
T_w	فترة التسخين (warmup)
جيب التمام	تناقص سلس حتى النهاية
تسخين	رفع تدريجي من الصفر

الرسم

<figure> الشكل<figcaption> 7.23: التسخين يرفع الخطوة أولاً لتجنّب عدم الاستقرار، ثمّ جيب التمام ينزلها بسلاسة.</figcaption> </figure>

البرهان (مخطّط)

التسخين يمنع الخطوات الكبيرة المبكرة مع تقديرات $m_0 = v_0 = 0$ غير الناضجة (من 6.23). الجيب التمام يوازن بين الاستكشاف السريع أولاً والاستقرار الدقيق أخيراً، ويتفوّق عملياً على التناقص الخطّي/الدرجي. ■

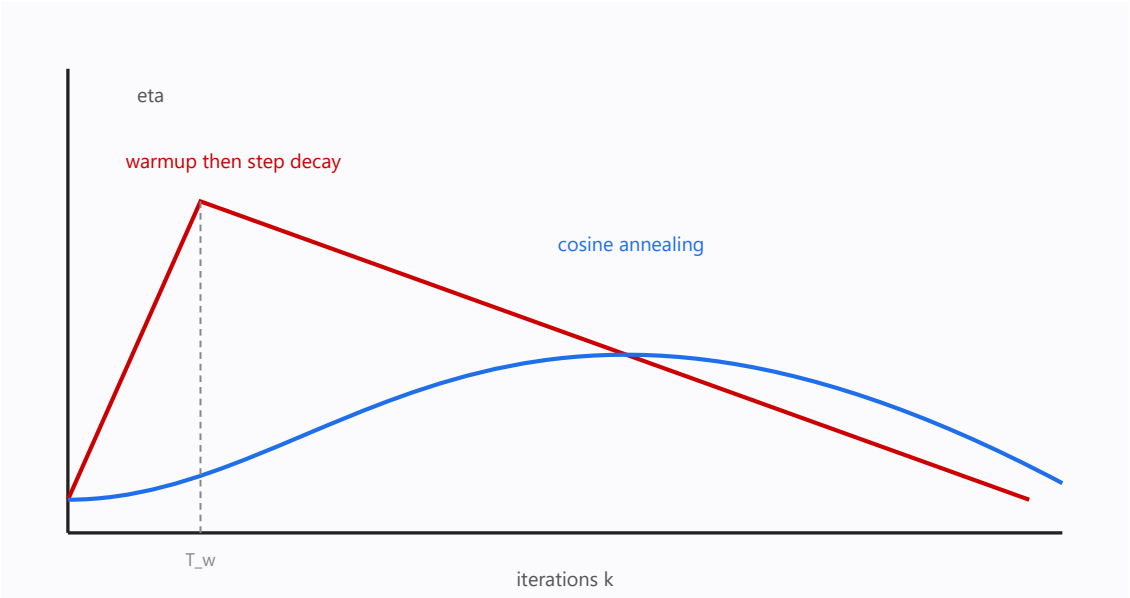
خمسة عشر مثالاً محلولاً

مثال (8.23-1): التسخين المعطيات: $T_w = 1000$، $\eta_{\max} = 10^{-3}$، $k = 500$. المطلوب: η_k. الحل: الخطوة 1: $\eta = 5 \times 10^{-4} = \frac{500}{1000} \times 10^{-3}$. النتيجة: نصف الحدّ الأقصى. الربط بالذكاء الاصطناعي: بداية آمنة للتدريب.

مثال (8.23-2): لماذا التسخين المعطيات: Adam بـ $v_0 = 0$. المطلوب: الخطر. الحل: الخطوة 1: تقدير المقياس غير ناضج $\Rightarrow$ خطوات أولى غير مستقرّة. النتيجة: نرفع η تدريجياً. الربط بالذكاء الاصطناعي: تدريب المحوّلات.

مثال (8.23-3): جيب التمام في المنتصف المعطيات: $k = T/2$، $\eta_{\min} = 0$. المطلوب: η. الحل: الخطوة 1: $\cos(\pi/2) = 0 \Rightarrow \eta = \frac{1}{2}\eta_{\max}$. النتيجة: النصف. الربط بالذكاء الاصطناعي: جدولة سلسة.

مثال (8.23-4): النهاية المعطيات: $k = T$. المطلوب: η. الحل: الخطوة 1: $\cos\pi = -1 \Rightarrow \eta = \eta_{\min}$. النتيجة: خطوة دقيقة أخيرة. الربط بالذكاء الاصطناعي: ضبط نهائي للأوزان.



شكل ٧.٢٣: *
جدولة معدل التعلم: التسخين وجيب التمام

مثال (5-8.23): الجدولة الدرجية المعطيات: نضرب η بـ 1.0 عند عصور محدّدة. المطلوب: المقارنة. الحل: الخطوة 1: أبسط لكن يقفز فجأة فيزعج التدريب. النتيجة: جيب التمام أنعم. الربط بالذكاء الاصطناعي: اختيار الجدولة.

مثال (6-8.23): إعادة التشغيل الساخن المعطيات: نعيد رفع η دورياً. المطلوب: الفائدة. الحل: الخطوة 1: يهرّب من الأصغريات الضحلة ويحسّن التعميم. النتيجة: تقنية شائعة. الربط بالذكاء الاصطناعي: SGDR/cosine restarts.

مثال (7-8.23): التدرّج التراكمي المعطيات: ذاكرة محدودة. المطلوب: الحلّ. الحل: الخطوة 1: نجمع التدرّجات على عدّة دفعات صغيرة قبل التحديث. النتيجة: دفعة فعّالة أكبر. الربط بالذكاء الاصطناعي: تدريب على بطاقة واحدة.

مثال (8-8.23): قصّ التدرّج المعطيات: $\|g\|$ ينفجر. المطلوب: المعالجة. الحل: الخطوة 1: نقصّ إلى عتبة (من 6.21). النتيجة: استقرار. الربط بالذكاء الاصطناعي: المحوّلات/RNN العميقة.

مثال (9-8.23): اختيار حجم الدفعة المعطيات: بطاقة بذاكرة محدّدة. المطلوب: الاستراتيجية. الحل: الخطوة 1: نكبّر الدفعة قدر الإمكان مع تراكم عند الحاجة. النتيجة: استغلال أفضل للعتاد. الربط بالذكاء الاصطناعي: كفاءة التدريب.

مثال (10-8.23): L-BFGS عملياً المعطيات: نموذج متوسّط بدقّة عالية مطلوبة. المطلوب: الحكم. الحل: الخطوة 1: L-BFGS ممتاز للمحدّب/الدفعي (من 8.20). النتيجة: دقّة فائقة بخطوات قليلة. الربط بالذكاء الاصطناعي: تدريب نماذج صغيرة/علمية.

مثال (11-8.23): متى لا نستخدم L-BFGS المعطيات: شبكة عميقة بضوضاء. المطلوب: السبب. الحل: الخطوة 1: معادلة القاطع تفشل مع التدرّجات الصاخبة. النتيجة: نبقى مع Adam/SGD. الربط بالذكاء الاصطناعي: حدود الطرق شبه النيوتونية.

مثال (12-8.23): التدرّج الطبيعي تمهيداً المعطيات: هندسة المعلومات (من 7.15). المطلوب: العلاقة. الحل: الخطوة 1: نستبدل المقياس القطري بمقياس فيشر $\Rightarrow$ تحديث ثابت توزيعياً. النتيجة: تمهيد للفصل 29. الربط بالذكاء الاصطناعي: natural gradient.

مثال (13-8.23): جدول المقارنة المعطيات: نريد دليلاً. المطلوب: التلخيص. الحل: الخطوة 1: نيستروف+SGD للرؤية، AdamW للّغة/الضخمة، L-BFGS للمحدّب الصغير، SVRG للدقّة المحدّبة. النتيجة: خريطة قرار. الربط بالذكاء الاصطناعي: هندسة المحسّنات.

مثال (23.8-14): التشخيص العملي المعطيات: خسارة التدريب لا تنزل. المطلوب: الفحص. الحل: الخطوة 1: نجرّب η أصغر/أكبر، نفحص التسخين والقصّ. النتيجة: تحديد السبب. الربط بالذكاء الاصطناعي: تصحيح أخطاء التدريب.

مثال (23.8-15): خلاصة الجزء المعطيات: كلّ المحسّنات. المطلوب: الصورة. الحل: الخطوة 1: الضوضاء تُروَّض بالزخم، والتفاوت بالتكييف، والدقّة بتقليل التباين والجدولة. النتيجة: إطار موحّد. الربط بالذكاء الاصطناعي: تصميم محسّنات المستقبل.

أخطاء شائعة

- إلغاء التسخين في النماذج الضخمة فينهار التدريب بدايةً.
- استخدام جدولة درجية مفاجئة بلا تسوية.
- خلط decay weight مع جدولة η بلا حساب.
- تطبيق L-BFGS على تدرّجات صاخبة.

ملخّص النظريات

النظرية	المفهوم	متى نستخدمه
SGD 23.2	تقدير غير متحيّز، $O(1/\sqrt{K})$	تدريب واسع النطاق
الزخم 23.3	$v = \beta v + g$	أودية ضيّقة
نيستروف 23.4	تقييم في y_k	محدّب/رؤية
AdaGrad/RMSProp 23.5	تكييف قطري	ميزات متفاوتة
Adam/AdamW 23.6	زخم + تكييف	النماذج الضخمة
SVRG/SAGA 23.7	تقليل التباين	دقّة عالية محدّبة
الجدولة 23.8	تسخين + جيب التمام	كلّ التدريبات

عشرون تمريناً (مع إجابات مختصرة)

١. تحديث SGD؟ $(x - \eta \hat{g})$

٢. لماذا $\hat{g}$ غير متحيّز؟ $(\mathbb{E}[\nabla f_i] = \nabla f)$

٣. معدّل SGD للمحدّب؟ $(O(1/\sqrt{K}))$

٤. أثر حجم الدفعة على التباين؟ $(\propto 1/B)$

٥. تحديث الزخم؟ $(v = \beta v + g \text{، } x - \eta v)$

٦. تضخّم الزخم عند $\beta \to 1$؟ $(1/(1-\beta))$

٧. نقطة استباق نيستروف؟ $(y = x + \beta(x - x_{-1}))$

٨. معدّل نيستروف؟ $(O(1/k^2))$

٩. صيغة AdaGrad؟ $(\eta g / \sqrt{G + \epsilon})$

١٠. عيب AdaGrad؟ (المقام يتراكم بلا توقّف)

١١. ما يحلّه RMSProp؟ (متوسّط متحرّك أُسّي)

١٢. مكوّنات Adam؟ (m زخم، v مقياس، تصحيح انحياز)

١٣. لماذا التصحيح؟ ($m_0 = v_0 = 0$ منحياز)

١٤. فرق AdamW؟ (يفصل weight decay)

١٥. تقدير SVRG؟ ($\nabla f_i(x) - \nabla f_i(\tilde{x}) + \nabla f(\tilde{x})$)

١٦. متى تقلّ ذاكرة SVRG عن SVRG SAGA؟ (يخزّن d فقط)

١٧. معدّل SVRG لقوي التحدّب؟ (خطّي)

١٨. لماذا التسخين؟ (تقديرات المقياس غير ناضجة)

١٩. صيغة جيب التمام؟ ($\eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})(1 + \cos(\pi k/T))$)

٢٠. متى L-BFGS؟ (محدّب/دفعي بدقّة عالية)

فهرس الرموز

الرمز	المعنى
$\hat{g}_k$	تقدير التدرّج
β, β_1, β_2	معاملات الزخم والمقياس
m_k, v_k	لحظتا Adam
$\tilde{x}$	مرساة SVRG
η_k, T, T_w	الخطوة، الإجمالي، التسخين

مراجع

- Robbins & Monro — «A Stochastic Approximation Method».
- Polyak — «Some methods of speeding up the convergence».
- Nesterov — *Introductory Lectures on Convex Optimization*.
- Duchi, Hazan & Singer — «Adaptive Subgradient Methods (AdaGrad)».
- Kingma & Ba — «Adam: A Method for Stochastic Optimization».
- Loshchilov & Hutter — «Decoupled Weight Decay Regularization (AdamW)».
- Johnson & Zhang — «Accelerating Stochastic Gradient Descent using Variance Reduction (SVRG)».

خاتمة: بهذا الفصل نختم نظرية المحسّنات العشوائية. الفصل 24 يصعد إلى **التحسين على المتشعّبات**، حيث لا يكون فضاء المعاملات إقليديّاً بل سطحاً منحنياً — كالأوزان المتعامدة والمصفوفات ذات الرتبة الثابتة.

التحسين على المتشعّبات (Riemannian Optimization)

«حين تكون القيود سطحاً منحنياً، لا تسقط على السطح: تحرّك عليه.»

في الفصل الحادي والعشرين عالجنا القيود بالإسقاط والعقوبة. لكنّ بعض القيود ليست «صندوقاً» بل **سطحاً منحنياً**: مصفوفات متعامدة، اتّجاهات وحيدة، مصفوفات ذات رتبة ثابتة، مصفوفات موجبة التحديد. إسقاط هذه القيود قد يكون مكلفاً أو يفقد البنية. الحلّ الأنقى: **اعترف بالهندسة** وابنِ المحسّن على المتشعّب نفسه.

هذا الفصل يفترض معرفة بالهندسة التفاضلية وسيعاد شرحها ذاتياً؛ وهو تمهيد مباشر للفصل 48 (الهندسة التفاضلية في التعلّم).

سبع نظريات:

- **2.24 فضاء المماسّ والتدرّج الريماني** — أين «يتحرّك» التدرّج؟
- **3.24 الانكماش ونقل المتّجه** — كيف نخطو ونبقى على السطح؟
- **4.24 الهبوط التدرّجي الريماني** — الخوارزمية وتقاربها.
- **5.24 الهِسّية الريمانية ونيوتن** — الانحناء من الدرجة الثانية.
- **6.24 متشعّب الكرة** — الاتّجاهات الوحيدة.
- **7.24 متشعّب شتيفل** — القيود المتعامدة.
- **8.24 متشعّب الرتبة الثابتة ومصفوفات PSD** — تقليل الأبعاد البنيوي.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

نريد حلّ $\min_{x \in \mathcal{M}} f(x)$ حيث $\mathcal{M}$ متشعّب (manfiold) ناعم.

الرمز	المعنى
$\mathcal{M}$	المتشعّب
$T_x\mathcal{M}$	فضاء المماسّ عند x
$\operatorname{grad} f$	التدرّج الريماني
R_x	الانكماش (retraction)
$\mathcal{T}$	نقل المتّجه (vector transport)
P_{T_x}	الإسقاط على المماسّ
$\bar{f}$	امتداد f إلى الفضاء المحيط

التدرّج الريماني هو إسقاط التدرّج الإقليدي (لأيّ امتداد ناعم $\bar{f}$) على فضاء المماسّ:

$$\operatorname{grad} f(x) \;=\; P_{T_x\mathcal{M}}\big(\nabla \bar{f}(x)\big), \qquad T_x\mathcal{M} = \{\xi : \text{اتّجاهات حركة مشروعة عند } x\} \tag{1.24}$$

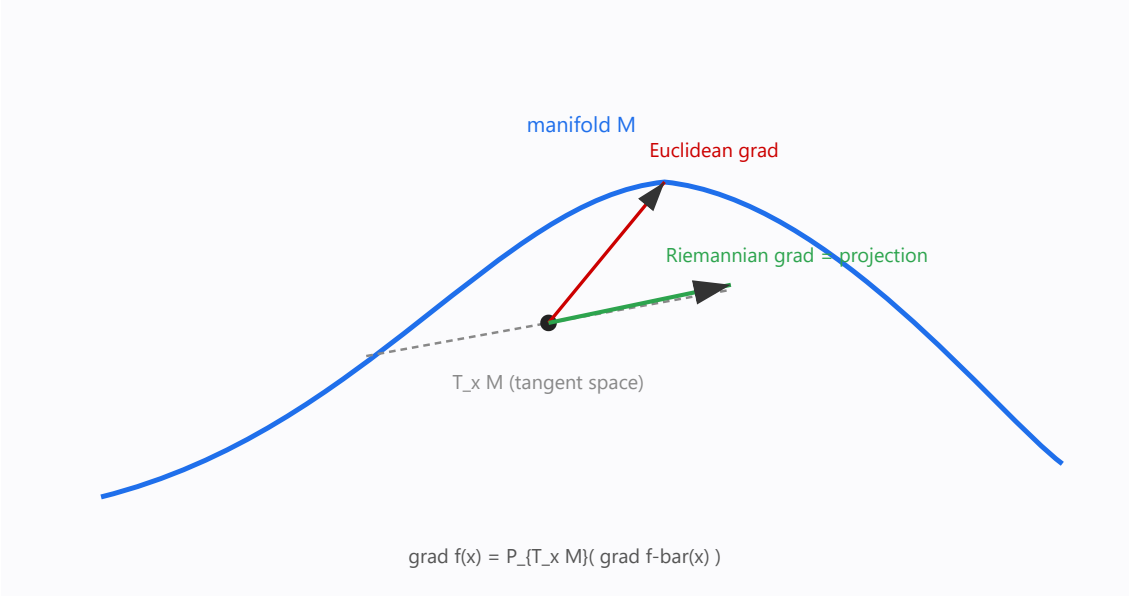
وهو المتّجه الوحيد في $T_x\mathcal{M}$ الذي يحقّق $\langle \operatorname{grad} f, \xi \rangle = \mathrm{D}f(x)[\xi]$ لكلّ $\xi \in T_x\mathcal{M}$.

جدول الرموز

الرمز	المعنى
$T_x\mathcal{M}$	فضاء المماسّ
ξ	متّجه مماسّي
P_{T_x}	إسقاط متعامد
$\langle \cdot,\cdot \rangle_x$	المقياس الريماني

الرسم

<figure> الشكل<figcaption> 1.24: نسقط التدرّج الإقليدي على فضاء المماسّ فنحصل على التدرّج



شكل ١٠٢٤: *
فضاء المماس والتدرج الريماني

الريماني.</figcaption> </figure>

البرهان (مخطّط)

بتعريف التدرّج كممثّل ريسز للتفاضل: نوجد $g \in T_x\mathcal{M}$ بحيث $\langle g, \xi \rangle = \mathrm{D}f(x)[\xi]$. وبما أنّ القيد على ξ مماسّي، فإسقاط $\nabla \bar{f}$ على $T_x\mathcal{M}$ يحقّق ذلك تماماً وهو وحيد. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.24): مماسّ الكرة المعطيات: $\mathcal{M} = S^{n-1} = \{x : \|x\| = 1\}$. المطلوب: $T_x\mathcal{M}$. الحل: الخطوة 1: نشتقّ القيد $\|x\|^2 = 1 \Rightarrow 2x^\top \xi = 0$. النتيجة: $T_x = \{\xi : x^\top \xi = 0\}$. الربط بالذكاء الاصطناعي: تحديث اتّجاه وحيد النُرم.

مثال (2-2.24): تدرّج ريماني على الكرة المعطيات: $\nabla \bar{f} = g$. المطلوب: grad$f$. الحل: الخطوة 1: $P = I - xx^\top$. النتيجة: نزيل مركّبة الشعاع. الربط بالذكاء الاصطناعي: تطبيع التضمينات/الأوزان.

مثال (3-2.24): التفسير الهندسي المعطيات: التدرّج الإقليدي يشير خارج السطح. المطلوب: لماذا نسقط؟ الحل:

الخطوة 1: الحركة الوحيدة المسموحة مماسّية؛ المركّبة العمودية عديمة الجدوى. النتيجة: الإسقاط يستخلص المفيد. الربط بالذكاء الاصطناعي: لماذا الإسقاط قبل التحديث؟.

مثال (4-2.24): مماسّ شتيفل المعطيات: $\mathrm{St}(p,n) = \{X : X^\top X = I_p\}$. المطلوب: T_X. الحل: الخطوة 1: نشتقّ القيد $X^\top\xi + \xi^\top X = 0 \Rightarrow$ (متماثل). النتيجة: فضاء المتّجهات «شبه المضادة للتماثل». الربط بالذكاء الاصطناعي: أوزان متعامدة/طبقات متعامدة.

مثال (5-2.24): تدرّج على شتيفل المعطيات: $G = \nabla \bar{f}$. المطلوب: $\mathrm{grad} f$. الحل: الخطوة 1: $G - X\,\mathrm{sym}(X^\top G)$ حيث $\mathrm{sym}(A) = \frac{A+A^\top}{2}$. النتيجة: إسقاط مماسّي. الربط بالذكاء الاصطناعي: تحديثات تحفظ التعامد.

مثال (6-2.24): نقطة حرجة ريمانية المعطيات: $\mathrm{grad} f(x) = 0$. المطلوب: المعنى. الحل: الخطوة 1: التدرّج مماسّياً يصفُر (لا بالضرورة إقليديّاً). النتيجة: شرط توقّف صحيح (من 2.20). الربط بالذكاء الاصطناعي: معيار توقّف على المتشعّب.

مثال (7-2.24): المقياس المعطيات: $\langle \xi, \eta \rangle_x$. المطلوب: الدور. الحل: الخطوة 1: يعرّف الأطوال والزوايا فيفضاء المماسّ. النتيجة: يحدّد شكل التدرّج. الربط بالذكاء الاصطناعي: مقاييس فيشر كمتشعّب (الفصل 29).

مثال (8-2.24): الامتداد $\bar{f}$ المعطيات: f معرّفة على المتشعّب فقط. المطلوب: كيف نحسب التدرّج؟ الحل: الخطوة 1: نختار امتداداً ناعماً للفضاء المحيط؛ الإسقاط يجعل النتيجة مستقلّة عنه. النتيجة: حرية الاختيار. الربط بالذكاء الاصطناعي: تنفيذ عملي بسيط.

مثال (9-2.24): مماسّ المصفوفات المتماثلة المعطيات: فضاء المصفوفات المتماثلة. المطلوب: T_X. الحل: الخطوة 1: الفضاء نفسه خطّي $\Rightarrow$ المماسّ = الفضاء. النتيجة: لا إسقاط مطلوب. الربط بالذكاء الاصطناعي: تحسين على مصفوفات التغاير.

مثال (10-2.24): مماسّ الرتبة الثابتة المعطيات: $\mathcal{M}_r = \{X : \mathrm{rank}(X) = r\}$. المطلوب: بنية T_X. الحل: الخطوة 1: $X = USV^\top \Rightarrow$ المماسّ يتكوّن من ثلاث كتل (انظر 8.24). النتيجة: فضاء بُعد $r(m+n-r)$. الربط بالذكاء الاصطناعي: تحديثات منخفضة الرتبة.

مثال (11-2.24): إسقاط مقابل عقوبة المعطيات: قيد متعامد. المطلوب: أيهما؟ الحل: الخطوة 1: المتشعّب أدقّ وأرخص من عقوبة بـ ρ كبير (من 7.21). النتيجة: تفضيل المتشعّب للقيود البنيوية. الربط بالذكاء الاصطناعي: تدريب بمصفوفات متعامدة.

مثال (12-2.24): الفرق عن الإسقاط المحدّب المعطيات: مجموعة محدّبة مقابل متشعّب. المطلوب: المقارنة. الحل: الخطوة 1: المحدّبة تبقى في فضاء إقليدي؛ المتشعّب منحنٍ محليّاً. النتيجة: أدوات مختلفة. الربط بالذكاء الاصطناعي: اختيار الإطار.

مثال (13-2.24): تدرّج على مبسّط المعطيات: قيد احتمالات (محدّب لا متشعّب). المطلوب: الملاحظة. الحل: الخطوة 1: محدّب بحدود $\Rightarrow$ الإسقاط كافٍ (من 6.21). النتيجة: لا حاجة لأدوات ريمانية. الربط بالذكاء الاصطناعي: متى نبقيه بسيطاً؟

مثال (14-2.24): التمثيل البرمجي المعطيات: نريد تنفيذgrad ريماني. المطلوب: الخطوات. الحل: الخطوة 1: نحسب التدرّج الإقليدي ثمّ نسقطه بصيغة المتشعّب. النتيجة: تنفيذ مباشر. الربط بالذكاء الاصطناعي: مكتبات Riemannian (مثل Geoopt/Manopt).

مثال (15-2.24): لماذا يهمّ التعلّم العميق المعطيات: شبكات بأوزان مقيدة بنيويّاً. المطلوب: الفائدة. الحل: الخطوة 1: المتشعّب يحفظ البنية ويحسّن الاستقرار والتعميم. النتيجة: تطبيقات حديثة. الربط بالذكاء الاصطناعي: orthogonal RNN/CNN وتطبيع الأوزان.

أخطاء شائعة

- استخدام التدرّج الإقليدي دون إسقاط.
- الخلط بين فضاء المماسّ والمتشعّب نفسه.
- افتراض أنّ المتشعّب محدّب (عادة ليس كذلك).
- نسيان أنّ شرط التوقّف مماسّي لا إقليدي.

الانكماش $R_x : T_x\mathcal{M} \to \mathcal{M}$ يحدّد خطوة على المتشعّب، و **نقل المتّجه** ينقل متّجهاً بين فضاءات المماسّ:

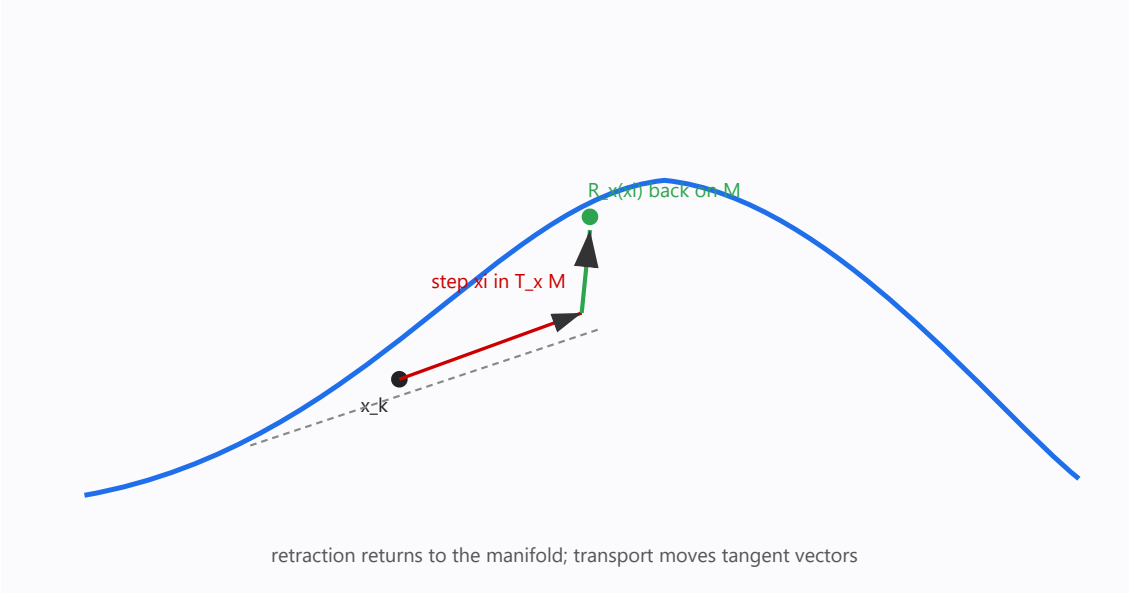
$$x_{k+1} = R_{x_k}(\xi_k), \quad R_x(0) = x, \quad \mathrm{D}R_x(0) = \mathrm{id}, \qquad \mathcal{T}_{x\to y} : T_x\mathcal{M} \to T_y\mathcal{M} \tag{2.24}$$

جدول الرموز

الرمز	المعنى
R_x	الانكماش (بديل الخريطة الأسّية)
ξ_k	متّجه الخطوة في المماسّ
$\mathcal{T}$	نقل المتّجه
خريطة أسّية	الانكماش الدقيق (geodesic)

الرسم

<figure> الشكل<figcaption> 2.24: نخطو في المماسّ ثمّ نعيد النقطة إلى المتشعّب بالانكماش؛ نقل المتّجه يحمل



شكل ٢٠٢٤: *
الانكماش ونقل المتجه على متشعب

الزخم.</figure> <figcaption/>

البرهان (مخطّط)

الشرطان $R_x(0) = x$ و $\mathrm{D}R_x(0) = \mathrm{id}$ يضمنان أنّ الخطوة الصغيرة تطابق الحركة المماسّية إلى الرتبة الأولى، فتصحّ تحليلات التقارب. نقل المتّجه يحافظ على الطول تقريباً فيسمح بتراكم الزخم. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.24): انكماش الكرة المعطيات: S^{n-1}، $\xi \in T_x$. المطلوب: $R_x(\xi)$. الحل: الخطوة 1: $R_x(\xi) = \frac{x+\xi}{\|x+\xi\|}$ (تطبيع). النتيجة: يبقى على الكرة. الربط بالذكاء الاصطناعي: تطبيع بعد التحديث.

مثال (2-3.24): لماذا ليس مجرّد جمع؟ المعطيات: $x + \xi$ عامّة. المطلوب: المشكلة. الحل: الخطوة 1: يخرج عن المتشعّب (النُرم $\neq 1$). النتيجة: نحتاج انكماشاً. الربط بالذكاء الاصطناعي: لماذا التطبيع ضروري؟

مثال (3-3.24): انكماش شتيفل المعطيات: $X + \xi$ مخالف للتعامد. المطلوب: $R_X(\xi)$. الحل: الخطوة 1: QR أو القطبيّة: $\mathrm{qf}(X+\xi)$. النتيجة: يعيد التعامد. الربط بالذكاء الاصطناعي: مصفوفات أوزان متعامدة.

مثال (4-3.24): الخريطة الأسّية المعطيات: نريد انكماشاً «دقيقاً». المطلوب: التعريف. الحل: الخطوة 1: نتحرّك على geodesic بطول $\|\xi\|$ باتّجاه ξ. النتيجة: الانكماش المثالي (أغلى حسابيّاً). الربط بالذكاء الاصطناعي: متى نحتاجه؟

مثال (5-3.24): الانكماش مقابل الإسقاط المعطيات: نعيد النقطة للمتشعّب. المطلوب: الفرق. الحل: الخطوة 1: الانكماش تحرّك داخلي؛ الإسقاط خارجي قد يكون مكلفاً. النتيجة: الانكماش أرخص غالباً. الربط بالذكاء الاصطناعي: كفاءة التنفيذ.

مثال (6-3.24): نقل المتّجه للكرة المعطيات: من x إلى y. المطلوب: $\mathcal{T}$. الحل: الخطوة 1: $\mathcal{T}_{x\to y}(\xi) = \xi - \frac{y^\top \xi}{1+x^\top y}(x+y)$ (نقل متعامد). النتيجة: يحفظ المماسّية. الربط بالذكاء الاصطناعي: زخم ريماني.

مثال (7-3.24): لماذا نقل المتّجه؟ المعطيات: نريد زخماً. المطلوب: التبرير. الحل: الخطوة 1: الزخم في فضاء مماسّ قديم لا ينتمي للجديد. النتيجة: ننقله أولاً. الربط بالذكاء الاصطناعي: momentum على المتشعّبات.

مثال (8-3.24): نقل بالإسقاط المعطيات: بديل بسيط. المطلوب: الطريقة. الحل: الخطوة 1: نُسقط المتّجه على المماسّ الجديد (نقل تقريبي). النتيجة: أرخص وأسهل. الربط بالذكاء الاصطناعي: تنفيذ مبسّط.

مثال (9-3.24): تراكم الزخم الريماني المعطيات: $\eta_k \in T_{x_k}\mathcal{M}$. المطلوب: التحديث. الحل: الخطوة 1: $\eta_{k+1} = \beta\mathcal{T}(\eta_k) + \mathrm{grad} f(x_{k+1})$. النتيجة: زخم صحيح هندسيّاً. الربط بالذكاء الاصطناعي: تسريع على المتشعّب.

مثال (10-3.24): الخطوة والانكماش المعطيات: $\xi = -\eta\,\mathrm{grad} f$. المطلوب: الترتيب. الحل: الخطوة 1: نحسب التدرّج، نضرب بالخطوة، ننكمش. النتيجة: تكرار كامل. الربط بالذكاء الاصطناعي: حلقة التدريب الريمانية.

مثال (11-3.24): انكماش الرتبة الثابتة المعطيات: تحديث منخفض الرتبة. المطلوب: إعادة الرتبة. الحل: الخطوة 1: SVD مقطوع إلى الرتبة r (من الفصل 4). النتيجة: انكماش طبيعي. الربط بالذكاء الاصطناعي: تحديثات منخفضة الرتبة/LoRA.

مثال (12-3.24): انكماش PSD المعطيات: مصفوفة موجبة التحديد. المطلوب: الانكماش. الحل: الخطوة 1: إسقاط طيفي بعد الخطوة (من 6.21). النتيجة: يبقى في المخروط. الربط بالذكاء الاصطناعي: مصفوفات تغاير/نواة.

مثال (13-3.24): دقّة الانكماش المعطيات: انكماش تقريبي. المطلوب: الحكم. الحل: الخطوة 1: إلى الرتبة الأولى يكفي لتحليل التقارب. النتيجة: لا حاجة للأسّي الدقيق. الربط بالذكاء الاصطناعي: مقايضة الدقّة/التكلفة.

مثال (14-3.24): التطبيع كطبقة المعطيات: طبقة تطبّع الأوزان. المطلوب: التفسير. الحل: الخطوة 1: هي انكماش على الكرة مطبّق كلّ تكرار. النتيجة: ربط بممارسة شائعة. الربط بالذكاء الاصطناعي: weight norm، normalization/spectral

مثال (15-3.24): الخطوة القصوى المعطيات: انكماش صالح محليّاً فقط. المطلوب: الحذر. الحل: الخطوة 1: خطوة

كبيرة قد تُفسد الانكماش ⇒ نحدّها أو نبحث خطّياً. النتيجة: استقرار عملي. الربط بالذكاء الاصطناعي: ضبط معدّل التعلّم الريماني.

أخطاء شائعة

- نسيان إعادة النقطة للمتشعّب بعد الخطوة.
- تراكم الزخم دون نقل للمتّجه.
- استخدام خطوة كبيرة بلا بحث خطّي.
- الخلط بين الانكماش والإسقاط المتعامد.

$$x_{k+1} = R_{x_k}\big(-\eta_k \operatorname{grad} f(x_k)\big), \qquad \min_{k} \|\operatorname{grad} f(x_k)\|^2 = O(1/K) \text{ (سلاسة مقارنة)} \tag{3.24}$$

ويتقارب كالمعدّل الإقليدي عند اختيار $\eta_k \le 1/L$ (سلاسة مقارنة على geodesic).

جدول الرموز

الرمز	المعنى
η_k	الخطوة
سلاسة مقارنة	$\lvert f(R_x(\xi)) - f(x) - \langle \operatorname{grad} f, \xi\rangle\rvert \le \frac{L}{2}\|\xi\|^2$
$O(1/K)$	معدّل نُرم التدرّج

الرسم

<figure> الشكل<figcaption> 3.24: كلّ تكرار: تدرّج مماسّي ← خطوة ← انكماش؛ المسار يبقى على السطح.</figcaption> </figure>

البرهان (مخطّط)

باستبدال متراجحة الهبوط الإقليدية (7.20) بنظيرتها «المقارنة» على geodesic: $f(x_{k+1}) \le f(x_k) - \eta(1 - \frac{\eta L}{2})\|\operatorname{grad} f\|^2$، ثمّ نجمع على k. ■

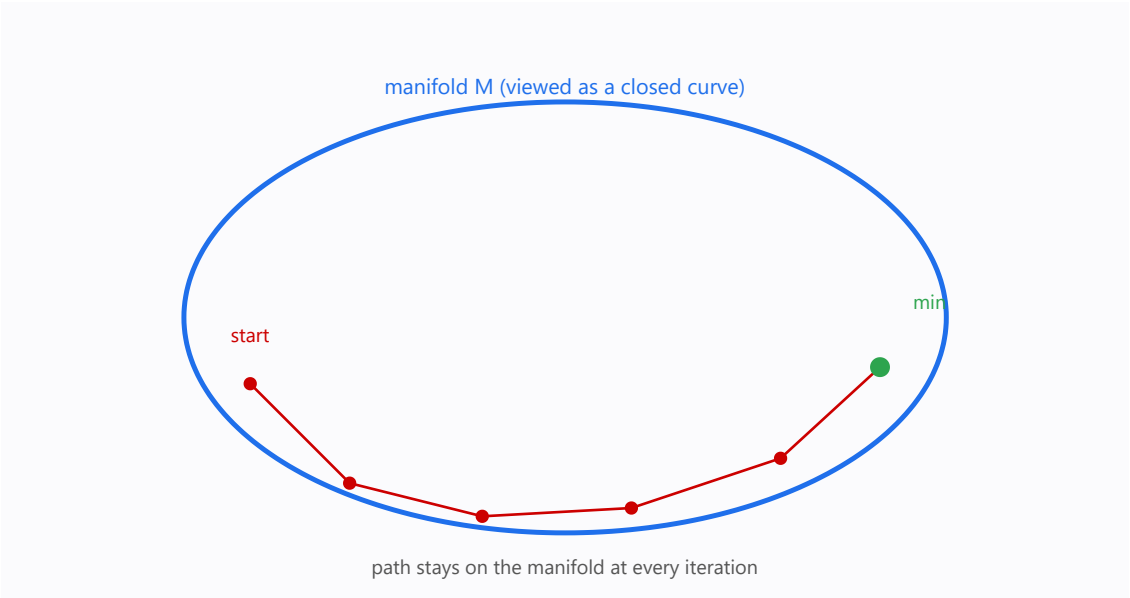
خمسة عشر مثالاً محلولاً

مثال (1-4.24): التكرار الكامل المعطيات: $\mathcal{M}$ كرة، g تدرّج إقليدي. المطلوب: خطوة واحدة. الحل: الخطوة 1: $\operatorname{grad} f = g - (x^\top g)x$. الخطوة 2: $x_+ = \frac{x - \eta \operatorname{grad} f}{\|x - \eta \operatorname{grad} f\|}$. النتيجة: تحديث على الكرة. الربط بالذكاء الاصطناعي: متّجهات وحيدة.

مثال (2-4.24): اختيار الخطوة المعطيات: L معلوم. المطلوب: η. الحل: الخطوة 1: $\eta \le 1/L$ (من 5.20 بالقياس). النتيجة: هبوط مضمون. الربط بالذكاء الاصطناعي: ضبط معدّل التعلّم.

مثال (3-4.24): معدّل التقارب المعطيات: سلاسة مقارنة. المطلوب: المعدّل. الحل: الخطوة 1: $O(1/K)$ في متوسط $\|\operatorname{grad} f\|^2$. النتيجة: مطابق للإقليدي. الربط بالذكاء الاصطناعي: ميزانية التكرارات.

مثال (4-4.24): البحث الخطّي الريماني المعطيات: نريد η تكيّفياً. المطلوب: الطريقة. الحل: الخطوة 1: نطبّق أرميخو على $f(R_x(-\eta \operatorname{grad} f))$ (من 6.20). النتيجة: متانة دون معرفة L. الربط بالذكاء الاصطناعي: بحث خطّي على المتشعّب.



شكل ٣.٢٤: *
الهبوط التدريجي الريماني

مثال (5-4.24): نقطة التوقّف المعطيات: $\epsilon < \|\text{grad} f\|$. المطلوب: الحكم. الحل: الخطوة 1: معيار توقّف صحيح (لا التدرّج الإقليدي). النتيجة: توقّف دقيق. الربط بالذكاء الاصطناعي: مراقبة التدريب.

مثال (6-4.24): مقارنة بالإسقاط المتكرّر المعطيات: هبوط + إسقاط مقابل ريماني. المطلوب: الفرق. الحل: الخطوة 1: الريماني يخطو داخل البنية فلا يفقد التقدّم. النتيجة: تقارب أنظف. الربط بالذكاء الاصطناعي: أفضلية الأسلوب الريماني.

مثال (7-4.24): PCA على الكرة المعطيات: $\max u^\top \Sigma u$ بـ $\|u\| = 1$. المطلوب: التكرار. الحل: الخطوة 1: $\text{grad} = 2(I - uu^\top)\Sigma u$ ثمّ نطبّع. النتيجة: يقارب المتّجه الذاتي الأول. الربط بالذكاء الاصطناعي: تعلّم المكوّن الرئيسي تدريجياً.

مثال (8-4.24): التدرّج الصاخب الريماني المعطيات: تقدير تدرّج بعيّنة. المطلوب: التعديل. الحل: الخطوة 1: نسقط التقدير ثمّ ننكمش. (RSGD) النتيجة: تدريب واسع النطاق على المتشعّب. الربط بالذكاء الاصطناعي: تدريب بمصفوفات متعامدة كبيرة.

مثال (9-4.24): الزخم الريماني المعطيات: نريد تسريعاً. المطلوب: الصيغة. الحل: الخطوة 1: ننقل الزخم بـ $\mathcal{T}$ ثمّ نجمعه مع التدرّج. النتيجة: تسريع صحيح. الربط بالذكاء الاصطناعي: محسّنات على المتشعّبات.

مثال (10-4.24): التكييف الريماني المعطيات: إحداثيات متفاوتة. المطلوب: المحسّن. الحل: الخطوة 1: نسخة ريمانية من Adam بتراكم في المماسّ مع نقل. النتيجة: تكييف على السطح. الربط بالذكاء الاصطناعي: مكتبات/RAdam حديثة.

مثال (11-4.24): التعامل مع الحدود المعطيات: متشعّب بحدود (مثل مصفوفات PSD). المطلوب: الحذر. الحل: الخطوة 1: الانكماش يجب ألّا يخرج عن المخروط. النتيجة: نستخدم إسقاطاً طيفياً. الربط بالذكاء الاصطناعي: تحسين على مخاريط.

مثال (12-4.24): التكلفة الحسابية المعطيات: n كبير. المطلوب: الحكم. الحل: الخطوة 1: الإسقاط والانكماش رخيصان عادة ($O(n)$ أو QR). النتيجة: قابل للتوسعة. الربط بالذكاء الاصطناعي: تدريب بميزانية محدودة.

مثال (13-4.24): التقارب العالمي المعطيات: نقطة بداية بعيدة. المطلوب: الضمان؟ الحل: الخطوة 1: غير محدّب

عموماً ⇒ ضمان محلّي فقط. النتيجة: نبدأ من تهيئات متعدّدة. الربط بالذكاء الاصطناعي: تهيئة النماذج.

مثال (4.24-14): التتبّع والتشخيص المعطيات: التدريب لا يتقدّم. المطلوب: الفحص. الحل: الخطوة 1: نتحقّق من نُرم $\operatorname{grad} f$ لا الإقليدي، وصحّة الانكماش. النتيجة: تحديد السبب. الربط بالذكاء الاصطناعي: تصحيح أخطاء التدريب.

مثال (4.24-15): متى نختار الريماني المعطيات: قيد بنيوي ناعم. المطلوب: الحكم. الحل: الخطوة 1: إذا كان القيد سطحاً ناعماً بلا حدود ⇒ الريماني مثالي. النتيجة: دليل اختيار. الربط بالذكاء الاصطناعي: قرارات هندسية.

أخطاء شائعة

- قياس التقدّم بالتدرّج الإقليدي.
- نسيان الانكماش فتخرج النقطة عن المتشعّب.
- توقّع ضمان عالمي في غير المحدّب.
- استخدام خطوة بلا مراعاة انحناء المتشعّب.

الهِسّية الريمانية تجمع إسقاط الهِسّية الإقليدية مع **تصحيح الانحناء** (الشكل الأساسي الثاني):

$$\operatorname{Hess} f(x)[\xi] \;=\; P_{T_x\mathcal{M}}\Big(\nabla^2 \bar{f}(x)[\xi]\Big) \;+\; \mathfrak{W}\big(x, \xi, P^{\perp}\nabla \bar{f}(x)\big) \tag{4.24}$$

ونيوتن الريماني يحلّ $\operatorname{Hess} f(x)[\xi] = -\operatorname{grad} f(x)$ ثمّ $x_+ = R_x(\xi)$.

جدول الرموز

الرمز	المعنى
$\operatorname{Hess} f$	الهِسّية الريمانية
$\mathfrak{W}$	حدّ الانحناء (Weingarten)
$P^{\perp}$	الإسقاط العمودي
معادلة نيوتن	تحديد اتّجاه الخطوة

الرسم

<figure> الشكل<figcaption> 4.24: الهِسّية الريمانية = إسقاط الهِسّية الإقليدية + تصحيح انحناء السطح.</figcaption>
</figure>

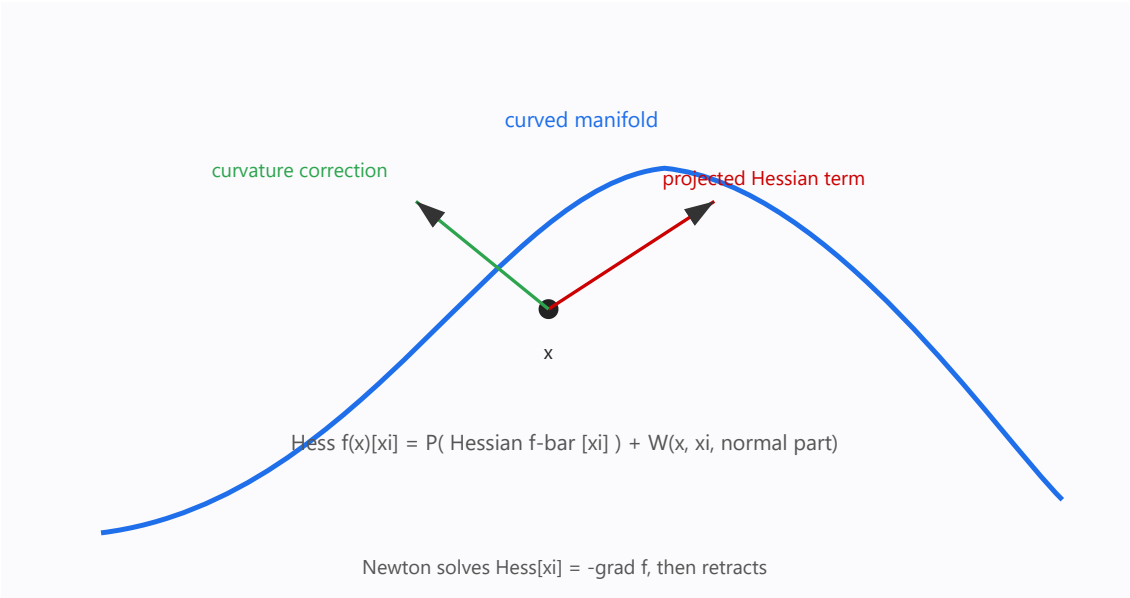
البرهان (مخطّط)

باشتراق التدرّج الريماني على طول الخطّ الجيوديسي: تتكوّن المشتقّة من تغيّر التدرّج الإقليدي (مسقوطاً) مضافاً إليه تغيّر الإسقاط نفسه عند تحرّك النقطة؛ الحدّ الثاني يعطي $\mathfrak{W}$. ■

خمسة عشر مثالاً محلولاً

مثال (5.24-1): هِسّية الكرة المعطيات: S^{n-1}. المطلوب: $\operatorname{Hess} f(x)[\xi]$. الحل: الخطوة 1: $P(\nabla^2 \bar{f}\,\xi) - (x^{\top}\nabla \bar{f})\xi$. النتيجة: إسقاط + حدّ انحناء. الربط بالذكاء الاصطناعي: انحناء على كرة الأوزان.

مثال (5.24-2): حدّ الانحناء المعطيات: سطح منحنٍ. المطلوب: لماذا نحتاجه؟ الحل: الخطوة 1: لأنّ فضاء المماسّ نفسه يتغيّر عند التحرّك. النتيجة: تجاهله يفسد الرتبة الثانية. الربط بالذكاء الاصطناعي: دقّة طرق نيوتن.



شكل ٤٠٢٤: *
الهسية الريمانية ونيوتن الريماني

مثال (3-5.24): نيوتن الريماني المعطيات: $\operatorname{grad} f$ و $\operatorname{Hess} f$. المطلوب: الخطوة. الحل: الخطوة 1: نحلّ المعادلة ثمّ ننكمش. النتيجة: تقارب تربيعي قرب الحلّ. الربط بالذكاء الاصطناعي: حلول دقيقة على المتشعّب.

مثال (4-5.24): معادلة نيوتن بالتدرّج المترافق المعطيات: نظام كبير. المطلوب: الحلّ. الحل: الخطوة 1: نحلّ بـ CG بضربات هِسّية بلا تخزين (من 8.20). النتيجة: كفاءة الذاكرة. الربط بالذكاء الاصطناعي: نيوتن ريماني واسع النطاق.

مثال (5-5.24): الانحناء القطعي المعطيات: سطح بانحناء موجب. المطلوب: الأثر. الحل: الخطوة 1: يعدّل شعور المشعر بالانحدار. النتيجة: أهمّيته في الدقّة العالية. الربط بالذكاء الاصطناعي: هندسة فضاء المعاملات.

مثال (6-5.24): نيوتن مقابل التدرّج المعطيات: نقطة قريبة من الحلّ. المطلوب: المقارنة. الحل: الخطوة 1: نيوتن أسرع بكثير (تربيعي مقابل خطّي). النتيجة: اختيار حسب المرحلة. الربط بالذكاء الاصطناعي: ضبط نهائي للنماذج.

مثال (7-5.24): trust-region الريماني المعطيات: هِسّية غير محدّدة. المطلوب: المعالجة. الحل: الخطوة 1: نحدّد نصف قطر في المماسّ ونقلّل نموذجاً (من 6.20). النتيجة: متانة في غير المحدّب. الربط بالذكاء الاصطناعي: تحسين متين.

مثال (8-5.24): هِسّية شتيفل المعطيات: $\operatorname{St}(p,n)$. المطلوب: الصيغة. الحل: الخطوة 1: إسقاط + حدّ يتضمّن $\operatorname{sym}(X^\top G)$. النتيجة: صيغة قابلة للتنفيذ. الربط بالذكاء الاصطناعي: تحسين متعامد دقيق.

مثال (9-5.24): التكلفة المعطيات: n كبير. المطلوب: الحكم. الحل: الخطوة 1: بناء الهِسّية مكلف $\Rightarrow$ نستخدم تقريبات/CG. النتيجة: مقايضة. الربط بالذكاء الاصطناعي: حدود نيوتن الريماني.

مثال (10-5.24): التحدّب الريماني المعطيات: $\operatorname{Hess} \succcurlyeq 0$ على geodesic. المطلوب: النتيجة. الحل: الخطوة 1: التحدّب geodesic يضمن عالمية النقطة الحرجة. النتيجة: نظير 4.20 على المتشعّب. الربط بالذكاء الاصطناعي: متى يضمن التدريب؟

مثال (11-5.24): الانحناء في التعلّم العميق المعطيات: فضاء الأوزان. المطلوب: الفائدة. الحل: الخطوة 1: فهم الانحناء يفسّر سلوك المحسّنات. النتيجة: رؤية نظرية. الربط بالذكاء الاصطناعي: تحليل مشهد الخسارة.

مثال (12-5.24): مصفوفات PSD المعطيات: مخروط التحديد الإيجابي. المطلوب: الملاحظة. الحل: الخطوة 1: له حدود $\Rightarrow$ نعامل الحدود بحذر في الهِسّية. النتيجة: طرق متخصّصة. الربط بالذكاء الاصطناعي: تحسين على المخاريط.

مثال (13-5.24): تقريب شبه نيوتن ريماني المعطيات: لا نريد الهِسّية الصريحة. المطلوب: البديل. الحل:

الخطوة 1: تحديث BFGS في المماسّ مع نقل المتّجهات. النتيجة: كفاءة قريبة من نيوتن. الربط بالذكاء الاصطناعي: RBFGS/L-BFGS ريماني.

مثال (14-5.24): التشخيص المعطيات: نيوتن لا يتقارب. المطلوب: الاحتمالات. الحل: الخطوة 1: هِسّية غير محدّدة أو انكماش خاطئ أو خطوة كبيرة. النتيجة: فحص منهجي. الربط بالذكاء الاصطناعي: تصحيح المحسّنات.

مثال (15-5.24): الخلاصة المعطيات: الرتبة الثانية على المتشعّب. المطلوب: الحكم. الحل: الخطوة 1: مفيدة للدقّة، مكلفة؛ نستخدمها عند الحاجة. النتيجة: دليل استخدام. الربط بالذكاء الاصطناعي: هندسة المحسّنات.

أخطاء شائعة

- تجاهل حدّ الانحناء في الهِسّية.
- تطبيق نيوتن بلا فحص التحديد الإيجابي.
- نسيان نقل المتّجهات في BFGS الريماني.
- توقّع تقارب عالمي بلا trust-region.

$$S^{n-1}=\{x\in\mathbb{R}^n:\|x\|=1\},\qquad T_xS=\{\xi:x^\top\xi=0\},\qquad R_x(\xi)=\frac{x+\xi}{\|x+\xi\|}\tag{5.24}$$

جدول الرموز

الرمز	المعنى
S^{n-1}	كرة الوحدة
$x^\top\xi=0$	شرط المماسّية
تطبيع	الانكماش على الكرة

الرسم

<figure> الشكل<figcaption> 5.24: فضاء المماسّ عمودي على الشعاع؛ الانكماش هو إعادة التطبيع.</figcaption>
</figure>

البرهان (مخطّط)

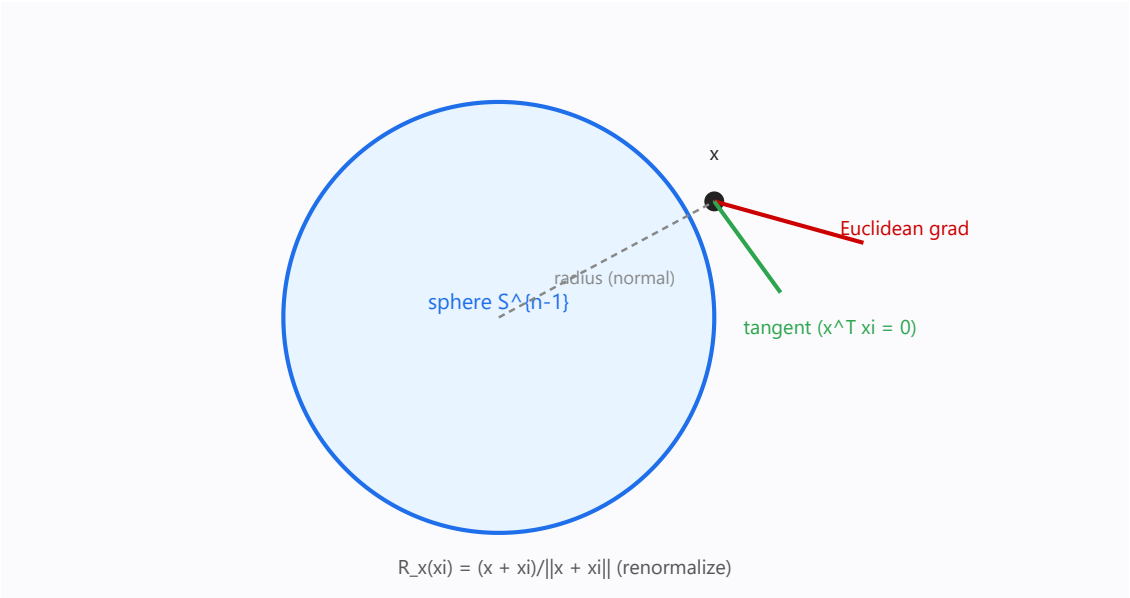
القيد $c(x)=\|x\|^2-1=0$؛ تدرّجه $2x$ عمودي على المماسّ، فالمماسّ هو $\{\xi:x^\top\xi=0\}$. الانكماش بالتطبيع يحقّق $R_x(0)=x$ و $\mathrm{D}R_x(0)=I-xx^\top$ (الإسقاط) $\Rightarrow$ انكماش صالح. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.24): مماسّ الكرة ثنائية الأبعاد المعطيات: $x=(1,0)$. المطلوب: T_xS. الحل: الخطوة 1: ξ بـ $\xi_1=0\Rightarrow$ المحور الرأسي. النتيجة: $\{(0,t)\}$. الربط بالذكاء الاصطناعي: حركة محلية على الدائرة.

مثال (2-6.24): إسقاط التدرّج المعطيات: $g=(3,4)$، $x=(1,0)$. المطلوب: $\mathrm{grad}f$. الحل: الخطوة 1: $g-(x^\top g)x=(3,4)-3(1,0)=(0,4)$. النتيجة: $(0,4)$. الربط بالذكاء الاصطناعي: إزالة مركّبة النُرم.

مثال (3-6.24): خطوة وانكماش المعطيات: $\eta=0.1$، $\mathrm{grad}=(1,-0.4)$. المطلوب: x_+. الحل: الخطوة 1: $x-\eta\,\mathrm{grad}=(0.928,-0.371)$. الخطوة 2: تطبّع. النتيجة: نقطة جديدة على الكرة. الربط بالذكاء الاصطناعي: تحديث تضمين وحيد.



شكل ٥.٢٤: *
متشعب الكرة والاتجاهات الوحيدة

مثال (4-6.24): PCA على الكرة المعطيات: Σ مصفوفة تغاير. المطلوب: المكوّن الأول. الحل: الخطوة 1: نكرّر grad ثمّ انكماش $\Rightarrow$ المتّجه الذاتي الأول. النتيجة: PCA تكراري (power method) مقارب). الربط بالذكاء الاصطناعي: تعلّم المكوّنات تدريجيّاً.

مثال (5-6.24): تطبيع الأوزان المعطيات: طبقة بأوزان مطبّعة. المطلوب: التفسير. الحل: الخطوة 1: القيد $\|w\| = 1$ $\Rightarrow$ تحديث ريماني على الكرة. النتيجة: استقرار التدريب. الربط بالذكاء الاصطناعي: weight normalization.

مثال (6-6.24): تضمينات وحيدة المعطيات: تضمينات كلمات مطبّعة. المطلوب: الفائدة. الحل: الخطوة 1: التشابه بالضرب النقطي يصير جيب التمام. النتيجة: تدريب مستقرّ. الربط بالذكاء الاصطناعي: embedding normalization.

مثال (7-6.24): عدم التحيّز بالمقياس المعطيات: نُرم ثابت. المطلوب: الأثر. الحل: الخطوة 1: يزيل درجة حرية غير مفيدة. النتيجة: فضاء بحث أصغر. الربط بالذكاء الاصطناعي: تقليل أبعاد فعّالة.

مثال (8-6.24): الكرة في الشبكات المعطيات: طبقة بمخرجات على الكرة. المطلوب: الاستخدام. الحل: الخطوة 1: تصنيف بتشابه جيب التمام (cosine). النتيجة: شائع في التضمينات. الربط بالذكاء الاصطناعي: metric learning (classfiiers).

مثال (9-6.24): الانحناء القطعي المعطيات: كرة وحدة. المطلوب: الانحناء. الحل: الخطوة 1: موجب ثابت $= 1$. النتيجة: أبسط مثال منحنٍ. الربط بالذكاء الاصطناعي: فهم حدّ الانحناء (5.24).

مثال (10-6.24): geodesic على الكرة المعطيات: بين نقطتين. المطلوب: المسار. الحل: الخطوة 1: الدائرة العظمى (great circle). النتيجة: أقصر مسار. الربط بالذكاء الاصطناعي: استيفاء على الكرة (slerp).

مثال (11-6.24): slerp المعطيات: تضمينان. المطلوب: الاستيفاء. الحل: الخطوة 1: الاستيفاء الكروي يحفظ النُرم. النتيجة: أفضل من الخطّي. الربط بالذكاء الاصطناعي: تداخل التضمينات/توليد.

مثال (12-6.24): التوزيع على الكرة المعطيات: توزيع اتّجاهي. المطلوب: المثال. الحل: الخطوة 1: توزيع فون ميزس–فيشر (von Mises–Fisher). النتيجة: غاوسي على الكرة. الربط بالذكاء الاصطناعي: نماذج اتّجاهية/توليدية.

مثال (13-6.24): التشابه المعطيات: نقطتان على الكرة. المطلوب: المقياس. الحل: الخطوة 1: $x^\top y = \cos\theta \Rightarrow$ الزاوية القوسية هي المسافة geodesic. النتيجة: هندسة واضحة. الربط بالذكاء الاصطناعي: مقاييس التشابه.

مثال (14-6.24): التحسين المشترك المعطيات: عدّة متّجهات وحيدة. المطلوب: الفضاء. الحل: الخطوة 1: حاصل

ضرب كرات ⇒ ما زال متشعّباً ناعماً. النتيجة: قابلية التوسعة. الربط بالذكاء الاصطناعي: طبقات متعدّدة متعامدة.

مثال (15-6.24): خلاصة الكرة المعطيات: متى نستخدمها؟ المطلوب: الحكم. الحل: الخطوة 1: كلّما كان النُرم ثابتاً بطبيعة المسألة. النتيجة: دليل تطبيق. الربط بالذكاء الاصطناعي: قرارات تصميم النماذج.

أخطاء شائعة

- نسيان التطبيع بعد التحديث.
- استخدام مسافة إقليدية بدل الزاوية القوسية.
- الخلط بين الكرة والقرص (كرة = سطح فقط).
- تجاهل انحناء الكرة في الرتبة الثانية.

$$\mathrm{St}(p,n)=\{X\in\mathbb{R}^{n\times p}: X^\top X=I_p\},\qquad T_X\mathrm{St}=\{\xi: X^\top\xi+\xi^\top X=0\}\tag{6.24}$$

والإسقاط المماسّي: $P_{T_X}(G)=G-X\,\mathrm{sym}(X^\top G)$.

جدول الرموز

الرمز	المعنى
$\mathrm{St}(p,n)$	متشعّب شتيفل (أعمدة متعامدة)
I_p	مصفوفة الوحدة
$\mathrm{sym}(A)$	الجزء المتماثل $\frac{A+A^\top}{2}$
qf	إعادة التعامد (قطبي/QR)

الرسم

<figure> الشكل<figcaption> 6.24: أعمدة متعامدة؛ فضاء المماسّ يفرض مضادّ تماثل في الإحداثيات المحلية.</figcaption> </figure>

البرهان (مخطّط)

نشتقّ $X^\top X=I\Rightarrow \xi^\top X+X^\top\xi=0$. الإسقاط: نبحث عن XA (بـ A متماثل) بحيث $G-XA$ مماسّي، فـ $A=\mathrm{sym}(X^\top G)\Rightarrow X^\top(G-XA)+(G-XA)^\top X=0$. ■

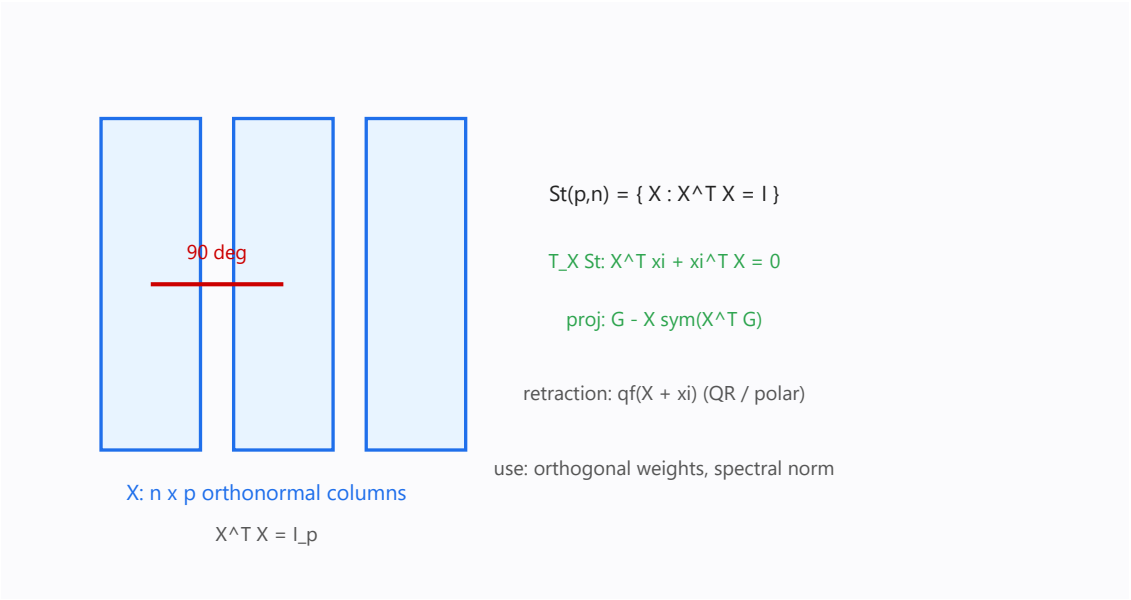
خمسة عشر مثالاً محلولاً

مثال (1-7.24): اختبار التعامد المعطيات: $X^\top X=I_2$. المطلوب: هل على شتيفل؟ الحل: الخطوة 1: نتحقّق من المصفوفة. النتيجة: نعم. الربط بالذكاء الاصطناعي: أوزان متعامدة.

مثال (2-7.24): إسقاط مماسّي المعطيات: G عشوائي و X. المطلوب: $P_{T_X}(G)$. الحل: الخطوة 1: $A=\mathrm{sym}(X^\top G)$ ثمّ $G-XA$. النتيجة: متّجه مماسّي. الربط بالذكاء الاصطناعي: تدرّج ريماني للمتعامد.

مثال (3-7.24): انكماش QR المعطيات: $X+\xi$. المطلوب: إعادة التعامد. الحل: الخطوة 1: $\mathrm{qf}(X+\xi)$ (عامل Q من QR). النتيجة: نقطة على شتيفل. الربط بالذكاء الاصطناعي: تحديث أوزان متعامدة.

مثال (4-7.24): الانكماش القطبي المعطيات: نفس المسألة. المطلوب: بديل. الحل: الخطوة 1: التحليل القطبي (polar) ⇒ أقرب مصفوفة متعامدة. النتيجة: انكماش بديل. الربط بالذكاء الاصطناعي: خيارات التنفيذ.



شكل ٦.٢٤: *
متشعب شتيفل والقيود المتعامدة

مثال (5-7.24): PCA متعدّد المعطيات: نريد p مكوّنات. المطلوب: الصياغة. الحل: الخطوة 1: $\max \operatorname{tr}(X^\top \Sigma X)$ على شتيفل. النتيجة: فضاء المكوّنات الرئيسية. الربط بالذكاء الاصطناعي: PCA دفعي (subspace).

مثال (6-7.24): لماذا فضاء لا نقاط؟ المعطيات: p متّجهات. المطلوب: الملاحظة. الحل: الخطوة 1: المهمّ هو الفضاء المولَّد لا المتّجهات المفردة. النتيجة: متشعّب حاصل قسمة (Grassmann). الربط بالذكاء الاصطناعي: subspace methods.

مثال (7-7.24): متشعّب غراسمان المعطيات: لا يهمّ الدوران الداخلي. المطلوب: التعريف. الحل: الخطوة 1: $\mathrm{Gr}(p,n) = \mathrm{St}(p,n)/O(p)$. النتيجة: فضاء الفضاءات الجزئية. الربط بالذكاء الاصطناعي: مقارنة فضاءات الميزات.

مثال (8-7.24): طبقة متعامدة المعطيات: شبكة بطبقة متعامدة. المطلوب: الفائدة. الحل: الخطوة 1: تحفظ النُرم $\Rightarrow$ استقرار التدرّج (من 5.20). النتيجة: تدريب أعمق وأثبت. الربط بالذكاء الاصطناعي: orthogonal/spectral normalization.

مثال (9-7.24): التطبيع الطيفي المعطيات: نحدّ النُرم الطيفي. المطلوب: العلاقة. الحل: الخطوة 1: قيد على القيمة المفردة العظمى $\Rightarrow$ تحديث متعامد مقيس. النتيجة: تحكّم في Lipschitz (من 5.20). الربط بالذكاء الاصطناعي: regularization/GAN. norm spectral

مثال (10-7.24): RNN متعامدة المعطيات: مصفوفة الانتقال متعامدة. المطلوب: الفائدة. الحل: الخطوة 1: تمنع انفجار/تلاشي التدرّجات (من الفصل 38). النتيجة: ذاكرة أطول. الربط بالذكاء الاصطناعي: orthogonal RNNs.

مثال (11-7.24): الالتفاف المتعامد المعطيات: مرشّحات متعامدة. المطلوب: الأثر. الحل: الخطوة 1: يحفظ الطاقة ويحسّن التعميم. النتيجة: تدريب أكثر متانة. الربط بالذكاء الاصطناعي: orthogonal CNNs.

مثال (12-7.24): تكلفة QR المعطيات: $n \times p$ كبير. المطلوب: التكلفة. الحل: الخطوة 1: $O(np^2)$ لكلّ تكرار $\Rightarrow$ مقبول عادة. النتيجة: قابلية التوسعة. الربط بالذكاء الاصطناعي: تدريب بميزانية محدودة.

مثال (13-7.24): التهيئة المعطيات: بداية التدريب. المطلوب: الإجراء. الحل: الخطوة 1: نبدأ من مصفوفة متعامدة (QR لعشوائية). النتيجة: شرط أساسي. الربط بالذكاء الاصطناعي: تهيئة الطبقات.

مثال (14-7.24): القيود المتعامدة والضوضاء المعطيات: تدرّجات صاخبة. المطلوب: الحذر. الحل: الخطوة 1:

الانكماش بعد كلّ تحديث يثبّت المسار. النتيجة: تدريب مستقرّ. الربط بالذكاء الاصطناعي: تدريب بمصفوفات متعامدة واسعة.

مثال (7.24-15): خلاصة شتيفل المعطيات: متى نستخدمه؟ المطلوب: الحكم. الحل: الخطوة 1: كلّما كان التعامد بنيويّاً لا مجرّد تنظيم. النتيجة: دليل تطبيق. الربط بالذكاء الاصطناعي: تصميم طبقات الشبكات.

أخطاء شائعة

- نسيان إعادة التعامد بعد التحديث.
- الخلط بين شتيفل وغراسمان.
- استخدام إسقاط بسيط بدل الانكماش الصحيح.
- توقّع أنّ التعامد يكفي وحده للاستقرار.

لمصفوفة $X = USV^\top$ برتبة r، المماسّ هو:

$$T_X\mathcal{M}_r = \{UMV^\top + U_pV^\top + UV_p^\top : \ M \in \mathbb{R}^{r\times r},\ U_p \perp U,\ V_p \perp V\} \tag{7.24}$$

والانكماش بالـ SVD المقطوع (SVD truncated)، ومخروط $X \succ 0$ يعامل بالتحليل الطيفي.

جدول الرموز

الرمز	المعنى
$\mathcal{M}_r$	متشعّب المصفوفات ذات الرتبة r
U, V	المتّجهات المفردة اليسرى/اليمنى
SVD مقطوع	إعادة الرتبة بعد الخطوة
$X \succ 0$	موجبة التحديد (من 5.15)

الرسم

<figure> الشكل<figcaption> 7.24: تحديثات منخفضة الرتبة تبقى على المتشعّب؛ مصفوفات PSD تعيش في مخروط.</figcaption> </figure>

البرهان (مخطّط)

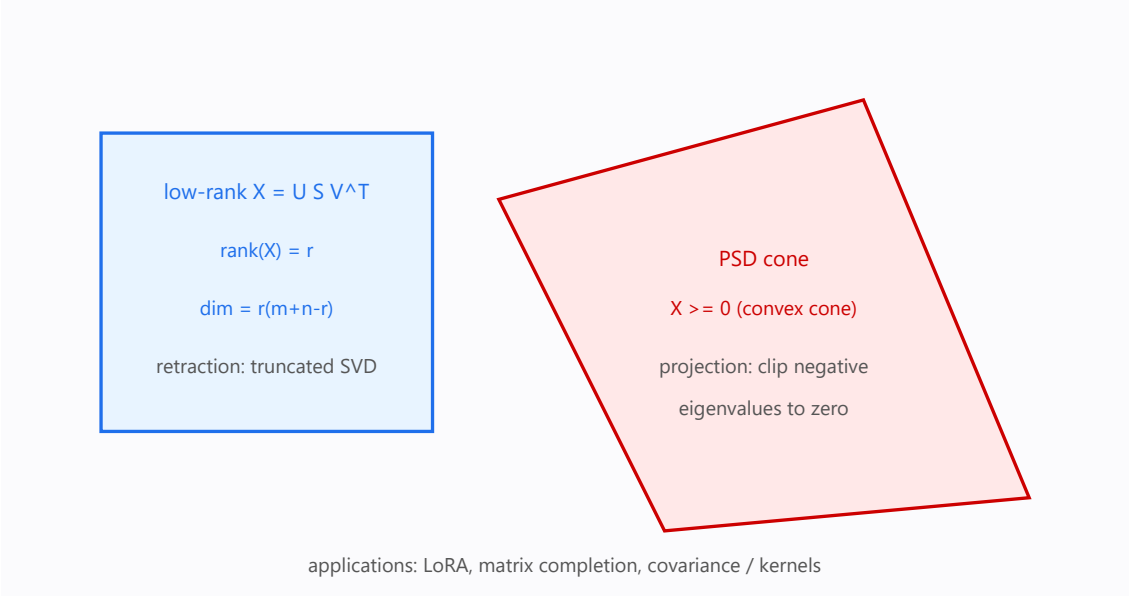
بكتابة $X = USV^\top$ واضطرابها، تتولّد ثلاث مركّبات مستقلّة: تغيير في S (عبر M)، وتغيير في U ضمن المكمّل العمودي (U_p)، وتغيير في V (V_p). البعد الناتج $r^2 + r(m-r) + r(n-r)$. ■

خمسة عشر مثالاً محلولاً

مثال (8.24-1): بُعد المماسّ المعطيات: $m = 100$، $n = 80$، $r = 5$. المطلوب: البعد. الحل: الخطوة 1: $r(m+n-r) = 5(175) = 875$. النتيجة: 875 درجة حرية. الربط بالذكاء الاصطناعي: توفير هائل مقابل 8000.

مثال (8.24-2): انكماش SVD المقطوع المعطيات: تحديث عامّ برتبة أعلى. المطلوب: إعادة الرتبة. الحل: الخطوة 1: نحسب SVD ونأخذ أكبر r قيمة مفردة (من الفصل 4). النتيجة: نقطة على $\mathcal{M}_r$. الربط بالذكاء الاصطناعي: تحديثات منخفضة الرتبة.

مثال (8.24-3): إكمال المصفوفة المعطيات: تقييمات ناقصة. المطلوب: الصياغة. الحل: الخطوة 1: نقلّل الخطأ على القيم المعروفة على $\mathcal{M}_r$. النتيجة: تصفية تعاونية. الربط بالذكاء الاصطناعي: أنظمة التوصية.



شكل ٢٤.٧: *
متشعب الرتبة الثابتة ومصفوفات موجبة التحديد

مثال (24.8-4): لماذا ليس النُرم النووي؟ المعطيات: بديل محدّب (من 22.4). المطلوب: المقارنة. الحل: الخطوة 1: النُرم النووي استرخاء محدّب، المتشعّب دقيق لكن غير محدّب. النتيجة: مقايضة ضمان/دقّة. الربط بالذكاء الاصطناعي: اختيار الطريقة.

مثال (24.8-5): LoRA وضبط دقيق منخفض الرتبة المعطيات: تحديث $\Delta W = BA$ برتبة منخفضة. المطلوب: التفسير. الحل: الخطوة 1: تحسين على متشعّب الرتبة المنخفضة (أو بعاملات صريحة). النتيجة: ضبط دقيق بمعاملات قليلة. الربط بالذكاء الاصطناعي: LoRA/PEFT.

مثال (24.8-6): مصفوفات PSD المعطيات: $X \succeq 0$. المطلوب: المجموعة. الحل: الخطوة 1: مخروط محدّب مغلق (من 22.2) لا متشعّب ناعم تماماً عند الحدود. النتيجة: نعامل الحدود بحذر. الربط بالذكاء الاصطناعي: مصفوفات التغاير/النواة.

مثال (24.8-7): إسقاط PSD المعطيات: مصفوفة بعد التحديث. المطلوب: التصحيح. الحل: الخطوة 1: تحليل ذاتي وقصّ القيم السالبة إلى صفر (من 21.6). النتيجة: يبقى في المخروط. الربط بالذكاء الاصطناعي: تحديث مصفوفة تغاير.

مثال (24.8-8): النُرم الطيفي المقيّد المعطيات: قيد على القيمة المفردة العظمى. المطلوب: المعالجة. الحل: الخطوة 1: قصّ طيفي بعد التحديث. النتيجة: تحكّم في Lipschitz. الربط بالذكاء الاصطناعي: spectral normalization.

مثال (24.8-9): تقليل أبعاد بنيوي المعطيات: مصفوفة أوزان ضخمة. المطلوب: الفائدة. الحل: الخطوة 1: نحسّن على $\mathcal{M}_r$ فتقلّ الذاكرة والحساب. النتيجة: تدريب فعّال. الربط بالذكاء الاصطناعي: نماذج مضغوطة.

مثال (24.8-10): التهيئة بالرتبة الصحيحة المعطيات: بداية التدريب. المطلوب: الإجراء. الحل: الخطوة 1: نبدأ من SVD مقطوع لأوّل تقدير. النتيجة: شرط أساسي. الربط بالذكاء الاصطناعي: تهيئة النماذج المضغوطة.

مثال (24.8-11): اختيار r المعطيات: لا نعرف الرتبة المناسبة. المطلوب: الاستراتيجية. الحل: الخطوة 1: نجرّب عدّة r ونقارن بالتحقّق (أو نزيدها تدريجياً). النتيجة: ضبط عملي. الربط بالذكاء الاصطناعي: اختيار هايبرمعاملات.

مثال (24.8-12): الانحناء عند الحدود المعطيات: رتبة تقترب من النقص. المطلوب: الخطر. الحل: الخطوة 1: المتشعّب يصير غير مغلق $\Rightarrow$ عدم استقرار. النتيجة: نثبّت r أو نستخدم صيغة عاملية. الربط بالذكاء الاصطناعي: استقرار التدريب المنخفض الرتبة.

مثال (24.8-13): الصيغة العاملية المعطيات: $X = LR^\top$. المطلوب: البديل. الحل: الخطوة 1: نحسّن على L, R

مباشرة (أبسط، بلا انكماش). النتيجة: تخلّي عن الدقّة الريمانية مقابل البساطة. الربط بالذكاء الاصطناعي: LoRA عمليّاً.

مثال (24.8-14): النواة والتغاير المعطيات: مصفوفة نواة يجب أن تكون PSD. المطلوب: المعالجة. الحل: الخطوة 1: قصّ طيفي أو تحسين داخل المخروط. النتيجة: نواة صالحة رياضيّاً. الربط بالذكاء الاصطناعي: Gaussian processes/kernels.

مثال (24.8-15): خلاصة الجزء المعطيات: كلّ المتشعّبات. المطلوب: الصورة. الحل: الخطوة 1: القيود البنيوية أسطح؛ نبني المحسّن عليها لا ضدّها. النتيجة: إطار موحّد للتعلّم المقيّد بنيويّاً. الربط بالذكاء الاصطناعي: مستقبل تصميم المحسّنات.

أخطاء شائعة

- نسيان إعادة الرتبة بعد التحديث.
- توقّع أنّ المتشعّب مغلق عند تدهور الرتبة.
- خلط الإسقاط الطيفي مع الانكماش الريماني.
- تجاهل أنّ مخروط PSD له حدود (ليس متشعّباً ناعماً everywhere).

ملخّص النظريات

النظرية	المفهوم	التطبيق
24.2 المماسّ والتدرّج	$P_{T_x}\nabla \bar{f}$	قيود ناعمة عامّة
24.3 الانكماش والنقل	$R_x, \mathcal{T}$	حركة على السطح
24.4 الهبوط الريماني	$R_x(-\eta \operatorname{grad} f)$	خوارزمية أساسية
24.5 الهِسّية ونيوتن	إسقاط + انحناء	دقّة عالية
24.6 الكرة	$x^\top \xi = 0$	تطبيع/تضمينات
24.7 شتيفل	$X^\top \xi + \xi^\top X = 0$	أوزان متعامدة
24.8 الرتبة الثابتة وPSD	SVD مقطوع/قصّ طيفي	إكمال LoRA/مصفوفة

عشرون تمريناً (مع إجابات مختصرة)

١. فضاء مماسّ الكرة؟ $(\{\xi : x^\top \xi = 0\})$

٢. تدرّج ريماني على الكرة؟ $(g - (x^\top g)x)$

٣. انكماش الكرة؟ $(\frac{x+\xi}{\|x+\xi\|})$

٤. شرطا الانكماش؟ $(R_x(0) = x$، $\mathrm{D}R_x(0) = \mathrm{id})$

٥. لماذا نقل المتّجه؟ (لتراكم الزخم بين فضاءات مماسّ)

٦. تكرار الهبوط الريماني؟ $(R_x(-\eta \operatorname{grad} f))$

٧. معيار التوقّف؟ $(\|\operatorname{grad} f\| < \epsilon)$

٨. مكوّنا الهِسّية الريمانية؟ (إسقاط + حدّ انحناء)

٩. معادلة نيوتن الريمانية؟ $(\operatorname{Hess}[\xi] = -\operatorname{grad} f)$

١٠. شتيفل؟ $(X^\top X = I)$

١١. مماسّ شتيفل؟ $(X^\top \xi + \xi^\top X = 0)$

١٢. إسقاط شتيفل؟ $(G - X\,\mathrm{sym}(X^\top G))$

١٣. انكماش شتيفل؟ QR) أو القطبيّة)

١٤. غراسمان؟ (شتيفل مقسوم على $O(p)$)

١٥. بُعد متشعّب الرتبة r؟ $(r(m+n-r))$

١٦. انكماش الرتبة؟ SVD) مقطوع)

١٧. إسقاط PSD؟ (قصّ القيم السالبة ذاتيّاً)

١٨. لماذا التعامد يثبّت التدرّج؟ (يحفظ النُرم)

١٩. علاقة LoRA بالمتشعّب؟ (تحسين منخفض الرتبة)

٢٠. متى لا نستخدم المتشعّب؟ (قيود محدّبة بسيطة يكفيها الإسقاط)

فهرس الرموز

الرمز	المعنى
$\mathcal{M}, T_x\mathcal{M}$	المتشعّب وفضاء المماسّ
grad, Hess	التدرّج والهِسّية الريمانية
$R_x, \mathcal{T}$	الانكماش ونقل المتّجه
S^{n-1}, St, Gr	الكرة، شتيفل، غراسمان
$\mathcal{M}_r$	متشعّب الرتبة الثابتة

مراجع

- Absil, P.-A., Mahony, R., & Sepulchre, R. — *Optimization Matrix on Algorithms Optimization*.
- Boumal, N. — *An Introduction to Optimization on Smooth Manifolds*.
- do Carmo, M. P. — *Riemannian Geometry*.
- Edelman, A., Arias, T. A., & Smith, S. T. — «The Geometry of Algorithms with Orthogonality Constraints».
- Vandereycken, B. — «Low-rank matrix completion by Riemannian optimization».

خاتمة: يختم هذا الفصل «التحسين البنيوي». الفصل 25 يختم الجزء الرابع بـ **التحسين الأسود والتوزيعي**، حيث لا نملك تدرّجاً أصلاً، أو نملك آلات كثيرة بدل تدرّج واحد.

التحسين التوزيعي والتحسين الأسود

«حين لا تملك تدرّجاً، اجعل كلّ تقييمٍ درساً؛ وحين تملك آلاتٍ كثيرة، اجعلها تعمل معاً.»

يختم هذا الفصل الجزء الرابع. حتى الآن افترضنا معرفةً بهيكل الهدف: تدرّجاً، تحدّباً، أو قيوداً. لكنّ كثيراً من مسائل الذكاء الاصطناعي لا تعطينا شيئاً من ذلك: تقييم واحد قد يكلّف ساعات من التدريب، ولا تدرّج متاح. وفي الوقت نفسه، قد نمتلك مئات العُقد بدل تدرّج واحد. هذا الفصل يعالج الحالتين.
سبع نظريات:

- **2.25 التحسين الأسود** — بلا تدرّج وبميزانية تقييمات.
- **3.25 العمليات الغاوسية** — نموذج بديل يعطي متوسطاً وانعدام يقين.
- **4.25 دالّة الاكتساب: التحسين المتوقّع (EI)** — أين نقيّم تالياً؟
- **5.25 UCB و PI** — بدائل EI ومقايضة الاستكشاف والاستغلال.
- **6.25 الندم التراكمي و bandits** — قياس جودة القرار المتسلسل.
- **7.25 التحسين التوزيعي** — توازي البيانات ومعلّم العاملات.
- **8.25 متوسط النماذج والتعلّم الاتحادي** — دمج النماذج بلا مركزية البيانات.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى
f	الهدف (صندوق أسود)
$\mathcal{D}_t$	مجموعة التقييمات حتى t
μ_t, σ_t	المتوسط والانحراف الخلفيّان للنموذج البديل
$\alpha(x)$	دالّة الاكتساب
R_T	الندم التراكمي
K	عدد العُقد/العملاء

المسألة: نريد $\min_{x \in \mathcal{X}} f(x)$ حيث لا نملك تدرّجاً، وتقييم f مكلف، ولا نملك سوى ميزانية T:

$$\text{الوصول: } \{(x_t, f(x_t))\}_{t=1}^{T} \qquad x^\star \in \arg\min_{x \in \mathcal{X}} f(x), \tag{1.25}$$

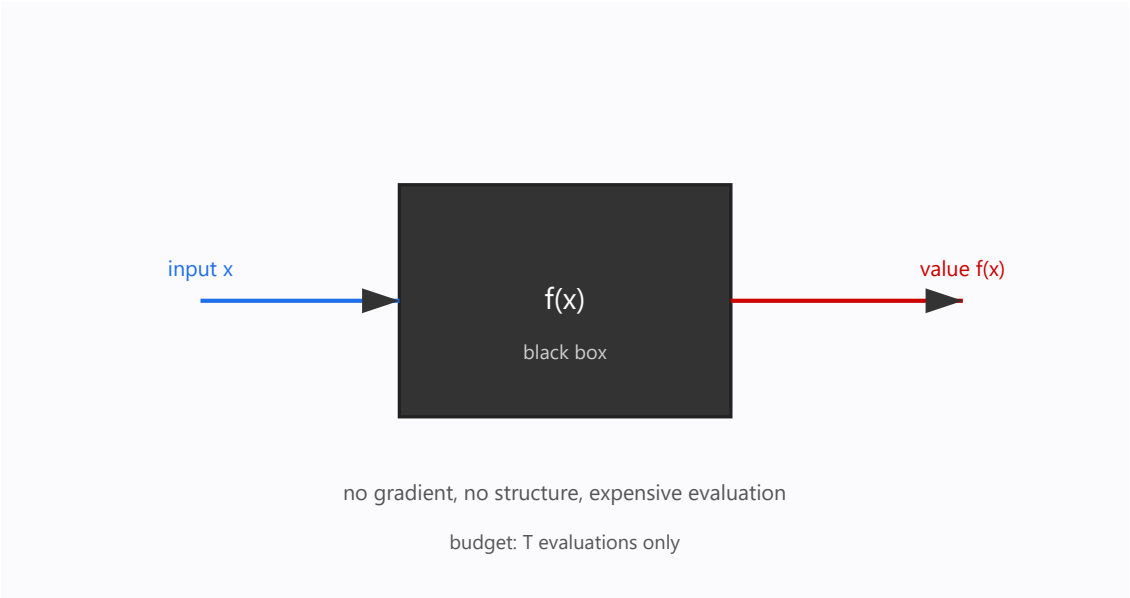
فالخوارزمية تختار x_{t+1} بناءً على التاريخ وحده.

جدول الرموز

الرمز	المعنى
$\mathcal{X}$	فضاء البحث
T	ميزانية التقييمات
صندوق أسود	لا تدرّج ولا بنية معلومة
تقييم مكلف	كلّ تجربة ثمينة

الرسم

<figure> الشكل<figcaption> 1.25: نعطي x فنستلم $f(x)$ فقط، لا تدرّج ولا بنية داخلية.</figcaption>



شكل ١.٢٥: *
التحسين الأسود: صندوق بلا تدرج

</figure>

البرهان (مخطّط)

بما أنّ المعلومات الوحيدة هي الأزواج $(x_t, f(x_t))$، فأيّ خوارزمية هي دالّة من التاريخ إلى النقطة التالية. الحدّ الأدنى للمعلومات يفرض أنّ التقدّم يعتمد على جودة نموذج بديل أو استراتيجية استكشاف، لا على خصائص محلية لـ f. ■

خمسة عشر مثالاً محلولاً

مثال (2.25-1): ضبط الهايبرمعاملات المعطيات: نموذج بمعدّل تعلّم وحجم طبقات. المطلوب: أفضل إعداد. الحل: الخطوة 1: كلّ إعداد يتطلّب تدريباً كاملاً (مكلف). الخطوة 2: لا تدرّج لـ «دقّة التحقّق» بالنسبة للإعدادات. النتيجة: مسألة صندوق أسود. الربط بالذكاء الاصطناعي: HPO في التدريب العملي.

مثال (2.25-2): بحث المعمارية المعطيات: بحث عن بنية شبكة. المطلوب: الأفضل. الحل: الخطوة 1: الفضاء متقطّع/هرمي؛ التقييم مكلف جدّاً. النتيجة: NAS مسألة سوداء. الربط بالذكاء الاصطناعي: Architecture Neural Search.

مثال (2.25-3): ضبط محرّك المعطيات: نظام إنتاج بمعاملات تشغيل. المطلوب: أفضل إعدادات أداء. الحل:

الخطوة 1: التقييم = قياس زمن الاستجابة الفعلي. النتيجة: تحسين أسود عملي. الربط بالذكاء الاصطناعي: ضبط أنظمة الاستدلال.

مثال (25.2-4): البحث الشبكي المعطيات: فضاء منفصل صغير. المطلوب: الطريقة الأساسية. الحل: الخطوة 1: نجرّب كلّ النقاط على شبكة. الخطوة 2: التكلفة تتضاعف أسّيّاً مع الأبعاد. النتيجة: يصلح لأبعاد قليلة فقط. الربط بالذكاء الاصطناعي: خطّ أساس بسيط.

مثال (25.2-5): البحث العشوائي المعطيات: أبعاد أعلى. المطلوب: البديل. الحل: الخطوة 1: نسحب نقاطاً عشوائيّاً من الفضاء. الخطوة 2: يتفوّق على الشبكي لأنّ الأبعاد غير متساوية الأهمّية. النتيجة: خطّ أساس قويّ. الربط بالذكاء الاصطناعي: search random في HPO.

مثال (25.2-6): لعنة الأبعاد المعطيات: 20 بُعداً. المطلوب: الصعوبة. الحل: الخطوة 1: حجم الفضاء ينمو أسّيّاً. النتيجة: التحسين الأسود يضعف فوق ~20 بُعداً. الربط بالذكاء الاصطناعي: حدّ BO العملي.

مثال (25.2-7): التقييم المتوازي المعطيات: نمتلك عدّة آلات. المطلوب: الاستفادة. الحل: الخطوة 1: نقيّم عدّة نقاط دفعة واحدة. النتيجة: تسريع الجداري الزمني. الربط بالذكاء الاصطناعي: ضبط متوازٍ.

مثال (25.2-8): الضجيج في التقييم المعطيات: نتيجة التقييم متذبذبة. المطلوب: الأثر. الحل: الخطوة 1: نحتاج نموذجاً يراعي الضجيج (noise). النتيجة: تعقيد إضافي. الربط بالذكاء الاصطناعي: تدريب ببذور مختلفة.

مثال (25.2-9): التوقّف المبكر المعطيات: تقييم يمكن إيقافه مبكراً. المطلوب: الفائدة. الحل: الخطوة 1: نوقف التجارب الواعدة قليلاً (Successive Halving). النتيجة: توفير كبير في الميزانية. الربط بالذكاء الاصطناعي: ASHA/Hyperband.

مثال (25.2-10): الفضاء الشرطي المعطيات: بعض المعاملات تعتمد على أخرى. المطلوب: الصعوبة. الحل: الخطوة 1: الفضاء ليس صندوقاً بسيطاً بل هرميّاً. النتيجة: نحتاج خوارزمية واعية بالبنية. الربط بالذكاء الاصطناعي: TPE/BOHB.

مثال (25.2-11): مقارنة بالتحسين التدرّجي المعطيات: هل نستخدم BO دائماً؟ المطلوب: الحكم. الحل: الخطوة 1: التدرّج أرخص بكثير إن توفّر. النتيجة: BO للضرورة لا للترف. الربط بالذكاء الاصطناعي: اختيار الطريقة.

مثال (25.2-12): التكلفة مقابل الدقّة المعطيات: ميزانية 50 تقييماً. المطلوب: التوقّع. الحل: الخطوة 1: BO يحقق غالباً نتائج جيدة بعشرات التقييمات. النتيجة: كفاءة عالية. الربط بالذكاء الاصطناعي: ميزانية التجارب.

مثال (25.2-13): تحسين السياسات المعطيات: سياسة تحكّم بمعاملات. المطلوب: الضبط. الحل: الخطوة 1: التقييم = تشغيل فعلي في المحاكاة/الواقع. النتيجة: تحسين أسود في الروبوتات. الربط بالذكاء الاصطناعي: sim-to-real/RL.

مثال (25.2-14): التصميم التجريبي المعطيات: نريد أقصى معلومات بأقلّ تجارب. المطلوب: المبدأ. الحل: الخطوة 1: نختار نقاطاً تقلّل عدم اليقين (استكشاف) أو تعظّم الكسب (استغلال). النتيجة: جوهر BO (4.25). الربط بالذكاء الاصطناعي: active learning.

مثال (25.2-15): متى نلجأ للأسود؟ المعطيات: ملخّص القرار. المطلوب: القاعدة. الحل: الخطوة 1: لا تدرّج + تقييم مكلف + أبعاد قليلة ⇒ BO مثالي. النتيجة: دليل تطبيق. الربط بالذكاء الاصطناعي: قرارات هندسية.

أخطاء شائعة

- استخدام البحث الشبكي في أبعاد عالية.
- تجاهل ضجيج التقييم فيفقد النموذج الثقة.
- توقّع أداءً جيداً لـ BO فوق 20 بُعداً.

- هدر الميزانية بتقييمات متكرّرة في نفس النقطة.

نضع سابقاً على f: $f \sim \mathcal{GP}(m, k)$، فنحصل بعد رؤية $\mathcal{D}_t$ على خلفيّة غاوسية:

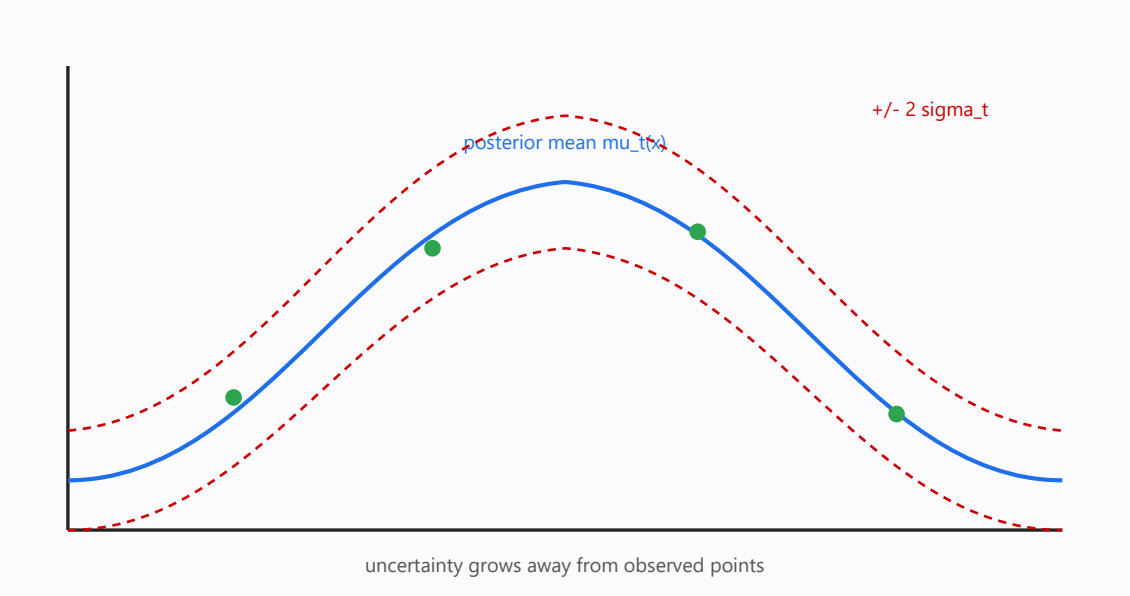
$$\mu_t(x) = m(x) + k(x)^\top (K + \sigma_n^2 I)^{-1}(y - m), \qquad \sigma_t^2(x) = k(x,x) - k(x)^\top (K + \sigma_n^2 I)^{-1} k(x) \tag{2.25}$$

جدول الرموز

الرمز	المعنى
m	دالّة المتوسط السابقة
k	دالّة النواة (kernel)
K	مصفوفة النواة على النقاط المرصودة
σ_n^2	تباين الضجيج
μ_t, σ_t	المتوسط والانحراف الخلفيّان

الرسم

<figure> الشكل<figcaption> 2.25: المتوسط يمرّ بالملاحظات، وعدم اليقين يتوسّع بعيداً عنها.</figcaption>



شكل ٢.٢٥: *
العمليات الغاوسية كنموذج بديل

</figure>

البرهان (مخطّط)

بالسابق الغاوسي، التوزيع المشترك للقيم المرصودة والقيمة الجديدة غاوسي مشترك؛ بالتكييف الغاوسي (من 6.15) نحصل على (2.25) مباشرة. ■

خمسة عشر مثالاً محلولاً

مثال (3.25-1): السابق والخلفيّة المعطيات: سابق GP بمتوسط صفر. المطلوب: بعد 3 ملاحظات. الحل: الخطوة 1: الخلفيّة ما زالت غاوسية لكن مشروطة. النتيجة: تحديث بايزي (من 16). الربط بالذكاء الاصطناعي: نموذج بديل قابل

للتحديث.

مثال (25.3.2-2): دور النواة المعطيات: نواة RBF. المطلوب: الأثر. الحل: الخطوة 1: تحدّد «نعومة» الدالّة ومدى التشابه. النتيجة: اختيار النواة = فرضية عن f. الربط بالذكاء الاصطناعي: kernel design.

مثال (25.3.3-3): عدم اليقين بعيداً المعطيات: نقطة بعيدة عن كلّ الملاحظات. المطلوب: σ_t. الحل: الخطوة 1: يقترب من الانحراف السابق (كبير). النتيجة: يشجّع الاستكشاف. الربط بالذكاء الاصطناعي: لماذا BO يستكشف.

مثال (25.3.4-4): عند الملاحظات المعطيات: نقطة مرصودة. المطلوب: σ_t. الحل: الخطوة 1: يصغر (يقترب من ضجيج القياس). النتيجة: ثقة عالية. الربط بالذكاء الاصطناعي: تجنّب إعادة التقييم.

مثال (25.3.5-5): ضبط طول النواة المعطيات: length-scale صغير. المطلوب: الأثر. الحل: الخطوة 1: الدالّة تتغيّر بسرعة $\Rightarrow$ استكشاف أكثر. النتيجة: مقايضة نعومة/تعقيد. الربط بالذكاء الاصطناعي: ضبط هايبرمعاملات GP.

مثال (25.3.6-6): تقدير الهايبرمعاملات المعطيات: نريد ضبط النواة. المطلوب: الطريقة. الحل: الخطوة 1: نعظّم الاحتمال الهامشي (marginal likelihood). النتيجة: ضبط تلقائي. الربط بالذكاء الاصطناعي: تدريب GP.

مثال (25.3.7-7): التكلفة الحسابية المعطيات: t ملاحظات. المطلوب: التكلفة. الحل: الخطوة 1: تحليل مصفوفة $\Rightarrow O(t^3)$ يحدّ الميزانية (~مئات). النتيجة: حدّ عملي لـ BO. الربط بالذكاء الاصطناعي: متى نستخدم تقريبات؟

مثال (25.3.8-8): التقريبات المعطيات: t كبير. المطلوب: البديل. الحل: الخطوة 1: نقاط مرجعية/مجموعات متفرّقة (sparse GP). النتيجة: توسّع الميزانية. الربط بالذكاء الاصطناعي: GP واسعة النطاق.

مثال (25.3.9-9): الضجيج المعطيات: تقييمات متذبذبة. المطلوب: المعالجة. الحل: الخطوة 1: نضيف $\sigma_n^2 I$ فلا يمرّ الوسط بكلّ نقطة تماماً. النتيجة: نموذج واقعي. الربط بالذكاء الاصطناعي: تدريب ببذور عشوائية.

مثال (25.3.10-10): متوسط سابق معلوم المعطيات: لدينا حدس عن شكل f. المطلوب: الاستخدام. الحل: الخطوة 1: نضعه في $m(x)$ فيقلّل الحاجة لملاحظات. النتيجة: استغلال المعرفة السابقة. الربط بالذكاء الاصطناعي: نقل الخبرة.

مثال (25.3.11-11): نواة ماتيرن المعطيات: f غير سلسة تماماً. المطلوب: الاختيار. الحل: الخطوة 1: Matérn أقلّ نعومة من RBF $\Rightarrow$ أنسب. النتيجة: مرونة النمذجة. الربط بالذكاء الاصطناعي: اختيار النواة.

مثال (25.3.12-12): التنبؤ للاكتساب المعطيات: نحتاج μ, σ فقط. المطلوب: الأهمّية. الحل: الخطوة 1: كلّ دالّة اكتساب مبنية عليهما. النتيجة: وحدة التصميم. الربط بالذكاء الاصطناعي: BO عملياً.

مثال (25.3.13-13): المخرجات المتعدّدة المعطيات: نقيّم عدّة مقاييس. المطلوب: المعالجة. الحل: الخطوة 1: GP متعدّد المخرجات أو قيود منفصلة. النتيجة: BO مقيّد. الربط بالذكاء الاصطناعي: مفاضلة الدقّة/الكمون.

مثال (25.3.14-14): التهيئة المعطيات: بداية BO. المطلوب: الإجراء. الحل: الخطوة 1: نبدأ بعدّة نقاط عشوائية (أو Latin hypercube) قبل النموذج. النتيجة: أساس سليم للخلفيّة. الربط بالذكاء الاصطناعي: تصميم التجارب الأولي.

مثال (25.3.15-15): لماذا GP بالذات؟ المعطيات: بدائل (شبكة، أشجار). المطلوب: الحكم. الحل: الخطوة 1: GP يعطي عدم يقين محسوباً بنموذج بايزي صريح. النتيجة: سبب شيوعه في BO. الربط بالذكاء الاصطناعي: اختيار النموذج البديل.

أخطاء شائعة

- تجاهل ضجيج القياس فتتشوّه الخلفيّة.
- استخدام GP لآلاف الملاحظات بلا تقريب.
- اختيار نواة بلا تفكير في نعومة الهدف.
- توقّع ثقة عالية بعيداً عن كلّ الملاحظات.

ليكن $f_t^\star$ أفضل قيمة مرصودة؛ نختار النقطة التي تعظّم التحسين المتوقّع:

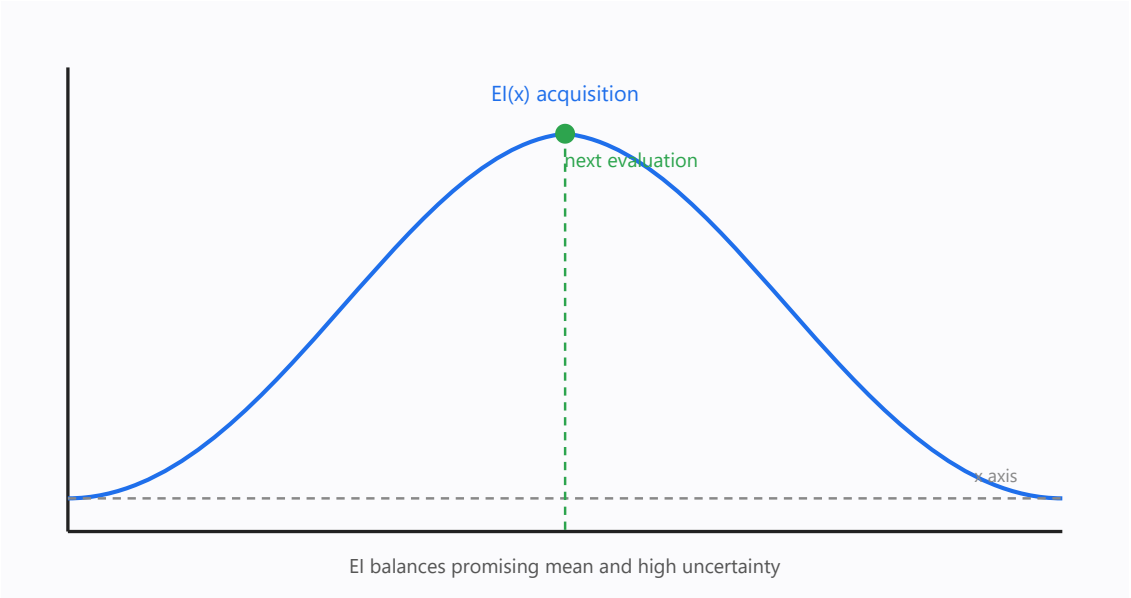
$$\alpha_{\mathrm{EI}}(x) = \mathbb{E}\big[\max(0,\, f_t^\star - f(x))\big] = \big(f_t^\star - \mu_t(x)\big)\Phi(z) + \sigma_t(x)\phi(z), \quad z = \frac{f_t^\star - \mu_t(x)}{\sigma_t(x)} \tag{3.25}$$

جدول الرموز

الرمز	المعنى
$f_t^\star$	أفضل قيمة حتى t
Φ, ϕ	دالّة التوزيع وكثافة الغاوسي القياسي
z	المسافة المعيارية عن الأفضل
α	دالّة الاكتساب

الرسم

<figure> الشكل<figcaption>3.25: EI تعظّم التوقّع الحسابي للتحسين؛ تتوازن بين المتوسط الواعد والانحراف



شكل ٣.٢٥: *
دالة الاكتساب: التحسين المتوقع

الكبير.</figcaption> </figure>

البرهان (مخطّط)

بما أنّ $f(x) \sim \mathcal{N}(\mu_t, \sigma_t^2)$، فإنّ $\mathbb{E}[\max(0, f^\star - f)] = \int_{-\infty}^{f^\star} (f^\star - u)\frac{1}{\sigma}\phi(\frac{u-\mu}{\sigma})du$. بالتعويض z وتكامل الأجزاء نحصل على الصيغة المغلقة (3.25). ■

خمسة عشر مثالاً محلولاً

مثال (1-4.25): حساب z المعطيات: $f^\star = 1$، $\mu = 1.5$، $\sigma = 0.5$. المطلوب: z. الحل: الخطوة 1: $z = (1 - 1.5)/0.5 = -1$. النتيجة: $z = -1$. الربط بالذكاء الاصطناعي: تقييم مرشّح.

مثال (2-4.25): EI عند المتوسط الأفضل المعطيات: $f^\star < \mu$ (واعد). المطلوب: سلوك EI. الحل: الخطوة 1: $z > 0 \Rightarrow$ EI كبيرة. النتيجة: استغلال. الربط بالذكاء الاصطناعي: تحسين حول الأفضل.

مثال (4.25-3): EI عند انحراف كبير المعطيات: $\mu = f^\star$ لكن σ كبير. المطلوب: السلوك. الحل: الخطوة 1: الحدّ $\sigma\phi(0)$ يعطي EI موجبة. النتيجة: استكشاف. الربط بالذكاء الاصطناعي: البحث في مناطق مجهولة.

مثال (4.25-4): EI عند يقين المعطيات: $\sigma \to 0$ و $\mu > f^\star$. المطلوب: EI. الحل: الخطوة 1: تقترب من صفر. النتيجة: لا نعيد التجربة. الربط بالذكاء الاصطناعي: كفاءة الميزانية.

مثال (4.25-5): تعظيم α المعطيات: نريد النقطة التالية. المطلوب: الإجراء. الحل: الخطوة 1: نعظّم α_{EI} على $\mathcal{X}$ (رخيص مقارنة بتقييم f). النتيجة: اختيار ذكي. الربط بالذكاء الاصطناعي: حلقة BO.

مثال (4.25-6): تكلفة تعظيم الاكتساب المعطيات: $\mathcal{X}$ متّصل. المطلوب: الطريقة. الحل: الخطوة 1: تحسين داخلي تدرّج/CMA-ES) متعدّد البدايات). النتيجة: عملي. الربط بالذكاء الاصطناعي: تنفيذ BO.

مثال (4.25-7): التوازن المعطيات: هل EI متوازنة؟ المطلوب: التفسير. الحل: الخطوة 1: الحدّ الأول استغلال (كم نتوقع تحسناً)؛ الثاني استكشاف (كم عدم يقين). النتيجة: توازن تلقائي. الربط بالذكاء الاصطناعي: مقايضة الاستكشاف/الاستغلال.

مثال (4.25-8): معلمة الاستكشاف المعطيات: نريد مزيد استكشاف. المطلوب: التعديل. الحل: الخطوة 1: نضيف ξ EI) مع «قفزة») أو ننتقل لـ UCB (5.25). النتيجة: تحكّم بالمقايضة. الربط بالذكاء الاصطناعي: ضبط BO.

مثال (4.25-9): EI للضجيج المعطيات: تقييمات صاخبة. المطلوب: التعديل. الحل: الخطوة 1: نستخدم «أفضل متوقّع» بدل أفضل مرصود. النتيجة: متانة. الربط بالذكاء الاصطناعي: BO صاخب.

مثال (4.25-10): EI والقيود المعطيات: قيد على مقياس آخر (كمون). المطلوب: المعالجة. الحل: الخطوة 1: نضرب بـ احتمال تحقيق القيد EI) مقيّد). النتيجة: BO مقيّد. الربط بالذكاء الاصطناعي: مفاضلة الدقّة/التكلفة.

مثال (4.25-11): الدفعات المعطيات: نريد 5 نقاط دفعة واحدة. المطلوب: الطريقة. الحل: الخطوة 1: نختار نقطة ثمّ نحدّث الخلفيّة «بافتراض مؤقّت» ثمّ نختار التالية. النتيجة: دفعة متنوّعة. الربط بالذكاء الاصطناعي: BO متوازٍ.

مثال (4.25-12): متى تفشل EI؟ المعطيات: فضاء منفصل كبير. المطلوب: الصعوبة. الحل: الخطوة 1: تعظيم α أصعب؛ نستخدم TPE أو تطوّراً. النتيجة: دليل اختيار. الربط بالذكاء الاصطناعي: HPO بمساحات هرمية.

مثال (4.25-13): EI مقابل البحث العشوائي المعطيات: ميزانية صغيرة. المطلوب: المقارنة. الحل: الخطوة 1: EI أفضل بكثير عند ميزانية صغيرة وأبعاد قليلة. النتيجة: تبرير BO. الربط بالذكاء الاصطناعي: اقتصاد التجارب.

مثال (4.25-14): التقارب المعطيات: BO يعمل طويلاً. المطلوب: الملاحظة. الحل: الخطوة 1: عدم اليقين يتقلّص، الاستكشاف يقلّ تلقائياً. النتيجة: استغلال متزايد. الربط بالذكاء الاصطناعي: سلوك متوقّع.

مثال (4.25-15): تلخيص الدور المعطيات: أين EI في الحلقة؟ المطلوب: الموضع. الحل: الخطوة 1: النموذج (3.25) ← الاكتساب (4.25) ← التقييم ← التحديث. النتيجة: حلقة BO الكاملة. الربط بالذكاء الاصطناعي: تصميم النظام.

أخطاء شائعة

- نسيان تحديث $f_t^\star$ بعد كلّ تقييم.
- استخدام أفضل مرصود مع ضجيج عالٍ.
- تعظيم α بجدّية أقلّ من اللازم فتضيع الفائدة.
- توقّع أنّ EI تعمل في أبعاد عالية جدّاً.

$$\alpha_{\text{UCB}}(x) = \mu_t(x) + \kappa_t\,\sigma_t(x), \qquad \alpha_{\text{PI}}(x) = \Phi\!\left(\frac{f_t^\star - \mu_t(x)}{\sigma_t(x)}\right) \tag{4.25}$$

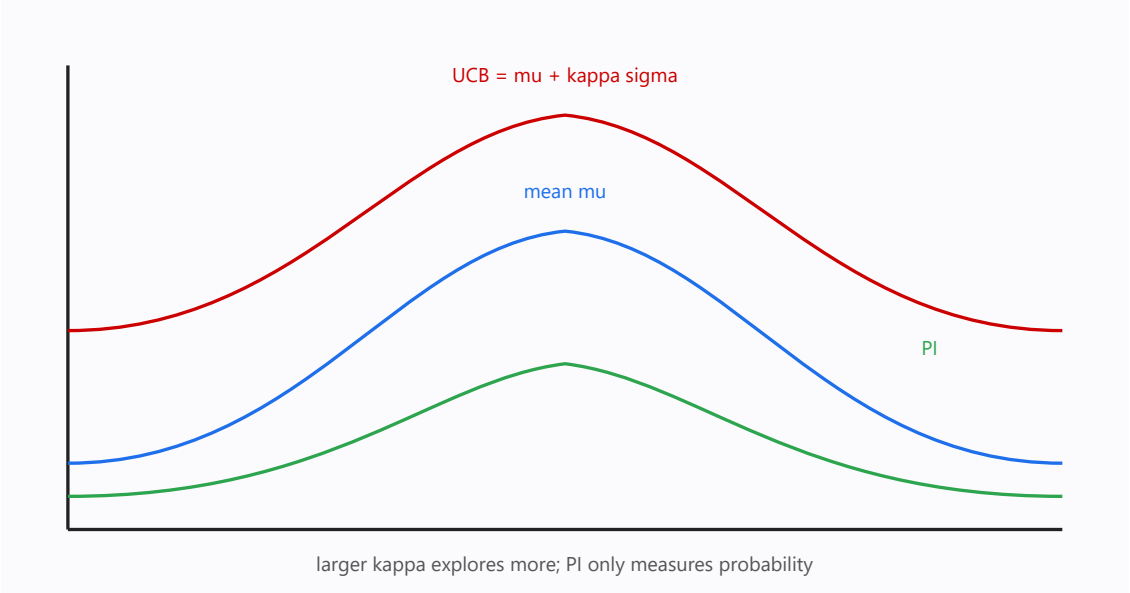
UCB تعظّم حدّاً أعلى واثقاً؛ PI تحسب احتمال التحسين فقط (بلا مقداره).

جدول الرموز

الرمز	المعنى
κ_t	معلمة الاستكشاف (تنمو ببطء)
UCB	Bound Confidence Upper
PI	Improvement of Probability
استكشاف/استغلال	مفاضلة أساسية

الرسم

<figure> الشكل<figcaption> 4.25: UCB ترفع المتوسط بـ $\kappa\sigma$؛ PI تحسب مساحة ذيل التحسين



شكل ٤.٢٥: *
UCB و PI ومقايضة الاستكشاف والاستغلال

فقط.</figcaption> </figure>

البرهان (مخطّط)

UCB مشتقّة من مبدأ «التفاؤل في وجه عدم اليقين»: نعامل أفضل سيناريو متوافقاً مع الخلفيّة. PI هي $\mathbb{P}(f(x) < f^\star)$ تحت الخلفيّة الغاوسية، أي $\Phi(z)$ مباشرة. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.25): حساب UCB المعطيات: $\mu = 2$، $\sigma = 0.5$، $\kappa = 2$. المطلوب: α. الحل: الخطوة 1: $2 + 2(0.5) = 3$. النتيجة: 3. الربط بالذكاء الاصطناعي: ترتيب المرشّحين.

مثال (25.5-2): أثر κ المعطيات: κ كبير. المطلوب: السلوك. الحل: الخطوة 1: يهيمن عدم اليقين $\Rightarrow$ استكشاف واسع. النتيجة: تحكّم مباشر. الربط بالذكاء الاصطناعي: ضبط المفاضلة.

مثال (25.5-3): κ صغير المعطيات: $\kappa = 0.1$. المطلوب: السلوك. الحل: الخطوة 1: يهيمن المتوسط $\Rightarrow$ استغلال. النتيجة: تحسين محلي. الربط بالذكاء الاصطناعي: استغلال معرفة قائمة.

مثال (25.5-4): حساب PI المعطيات: $z = 0.5$. المطلوب: PI. الحل: الخطوة 1: $\Phi(0.5) \approx 0.691$. النتيجة: $\approx 69\%$ احتمال تحسين. الربط بالذكاء الاصطناعي: تقييم الاحتمال.

مثال (25.5-5): عيب PI المعطيات: تحسين ضئيل جدّاً لكن مؤكّد. المطلوب: المشكلة. الحل: الخطوة 1: PI تعطي قيمة عالية رغم ضآلة الكسب. النتيجة: ميل للاستغلال المفرط. الربط بالذكاء الاصطناعي: لماذا EI أشيع؟

مثال (25.5-6): ميزة UCB النظرية المعطيات: نريد ضماناً. المطلوب: النتيجة. الحل: الخطوة 1: UCB لها حدود ندم معلومة في إطار bandits. النتيجة: قوة نظرية (6.25). الربط بالذكاء الاصطناعي: اختيار مدعوم نظريّاً.

مثال (25.5-7): مقارنة الثلاث المعطيات: EI/PI/UCB. المطلوب: الملخّص. الحل: الخطوة 1: EI توازن؛ UCB قابلة للضبط والضمان؛ PI بسيطة لكن متحيّزة للاستغلال. النتيجة: دليل اختيار. الربط بالذكاء الاصطناعي: تصميم BO.

مثال (25.5-8): الاستكشاف أولاً المعطيات: بداية التجارب. المطلوب: الاستراتيجية. الحل: الخطوة 1: κ أكبر أولاً ثمّ يتضاءل. النتيجة: استكشاف ثمّ استغلال. الربط بالذكاء الاصطناعي: جدولة الاستكشاف.

مثال (25.5-9): مفاضلة صريحة المعطيات: نريد تسمية الظاهرة. المطلوب: التعريف. الحل: الخطوة 1: استكشاف = تقليل عدم اليقين؛ استغلال = تعظيم الكسب المتوقّع. النتيجة: المفهوم المركزي. الربط بالذكاء الاصطناعي: يظهر أيضاً في RL (الفصل 44).

مثال (25.5-10): عيّنة طومسون المعطيات: بديل بايزي. المطلوب: الفكرة. الحل: الخطوة 1: نسحب دالّة من الخلفيّة ونعظّمها. النتيجة: استكشاف طبيعي بلا معلمة. الربط بالذكاء الاصطناعي: Thompson sampling.

مثال (25.5-11): UCB في الشبكات المعطيات: اختيار بين نماذج. المطلوب: التطبيق. الحل: الخطوة 1: نعامل كلّ نموذج كذراع بمتوسط وانحراف. النتيجة: اختيار متوازن. الربط بالذكاء الاصطناعي: A/B والاختيار التكيّفي.

مثال (25.5-12): التوسّع للأبعاد المعطيات: فضاء متّصل كبير. المطلوب: الحذر. الحل: الخطوة 1: تعظيم UCB/EI يصعب في أبعاد عالية. النتيجة: حدّ عملي. الربط بالذكاء الاصطناعي: حدود BO.

مثال (25.5-13): المعيار الخاطئ المعطيات: نختار بأفضل متوسّط فقط. المطلوب: المشكلة. الحل: الخطوة 1: لا استكشاف $\Rightarrow$ قد نعلق في محلي. النتيجة: أهمّية الحدّ الثاني. الربط بالذكاء الاصطناعي: لماذا نحتاج σ.

مثال (25.5-14): الضجيج و UCB المعطيات: تقييمات صاخبة. المطلوب: الأثر. الحل: الخطوة 1: σ لا يتقلّص تماماً $\Rightarrow$ استكشاف مستمرّ. النتيجة: سلوك متوقّع. الربط بالذكاء الاصطناعي: تشخيص BO.

مثال (25.5-15): خلاصة المفاضلة المعطيات: كلّ الطرق. المطلوب: القاعدة. الحل: الخطوة 1: كلّ دالّة اكتساب هي شكل من موازنة المتوسط مع عدم اليقين. النتيجة: وحدة المفهوم. الربط بالذكاء الاصطناعي: تصميم اكتساب جديد.

أخطاء شائعة

- استخدام PI وحدها فنبالغ في الاستغلال.
- تثبيت κ بلا جدولة.
- تجاهل أنّ الاستكشاف يحتاج ميزانية.
- الخلط بين احتمال التحسين ومقداره.

في إطار «ماكينات متعدّدة الأذرع»، نقيس الجودة بالندم التراكمي:

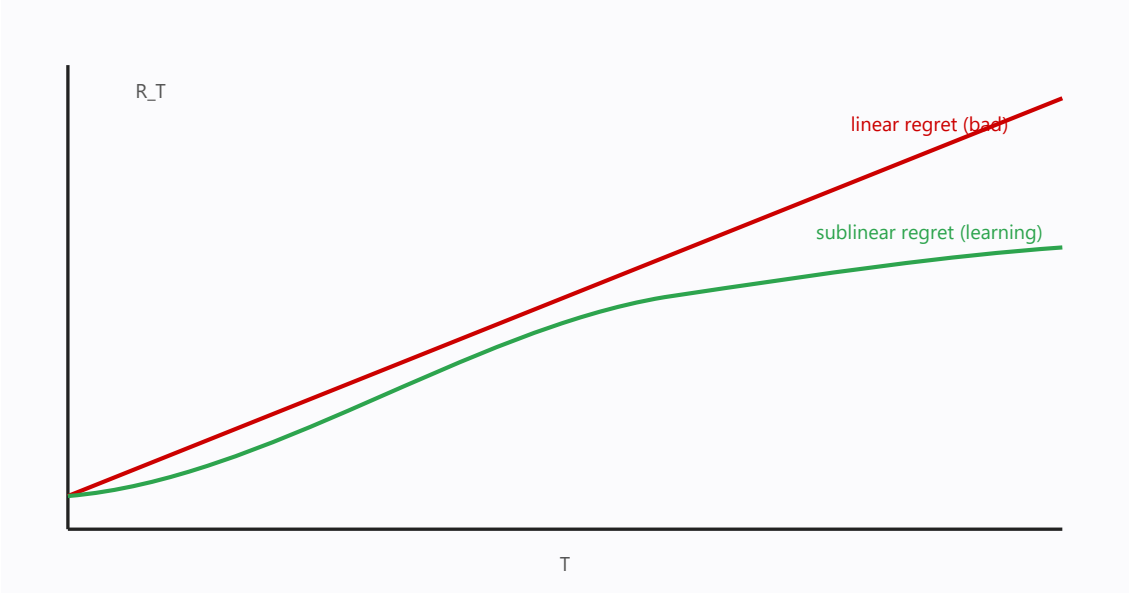
$$R_T = \sum_{t=1}^{T} \big(f(x^\star) - f(x_t)\big), \qquad \text{يحقّق UCB} R_T = O(\sqrt{T \log T}) \tag{5.25}$$

جدول الرموز

الرمز	المعنى
R_T	الندم التراكمي
$x^\star$	الخيار الأفضل
ذراع	خيار متاح
sublinear	تعلّم $\Rightarrow R_T/T \to 0$

الرسم

<figure> الشكل<figcaption> 5.25: الندم ينمو دون خطّي؛ كلّما كان النمو أبطأ كانت الاستراتيجية



شكل ٥.٢٥: *
الندم التراكمي وإطار bandits

أفضل.</figcaption> </figure>

البرهان (مخطّط)

نحلّل عدد مرّات اختيار الذراع دون المستوى: بالحدود التركيزية (الفصل 17) يتركّز المتوسط المقدَّر حول الحقيقي، فيُختار الذراع السيّء $O(\log T)$ مرة فقط $\Rightarrow$ (5.25). ■

خمسة عشر مثالاً محلولاً

مثال (5.25-1): تعريف الندم المعطيات: أفضل عائد 10، اخترنا ذراعاً بـ 7. المطلوب: الندم. الحل: الخطوة 1: $10 - 7 = 3$. النتيجة: 3 لهذه الخطوة. الربط بالذكاء الاصطناعي: تكلفة القرار الخاطئ.

مثال (25.6-2): الندم التراكمي المعطيات: 100 خطوة بمتوسط ندم 2. المطلوب: R_T. الحل: الخطوة 1: 200. النتيجة: مقياس الجودة. الربط بالذكاء الاصطناعي: تقييم السياسة.

مثال (25.6-3): الندم دون الخطّي المعطيات: $R_T = O(\sqrt{T})$. المطلوب: المعنى. الحل: الخطوة 1: $R_T/T \to 0 \Rightarrow$ نتعلّم تدريجيّاً. النتيجة: معيار النجاح. الربط بالذكاء الاصطناعي: تعريف التعلّم.

مثال (25.6-4): استراتيجية جشعة المعطيات: نختار دائماً الأفضل المرصود. المطلوب: العيب. الحل: الخطوة 1: قد نعلق بذراع سيّء باكراً. النتيجة: ندم خطّي. الربط بالذكاء الاصطناعي: لماذا الجشع يفشل؟

مثال (25.6-5): ϵ-جشع المعطيات: نستكشف بنسبة ϵ. المطلوب: الأثر. الحل: الخطوة 1: يضمن استكشافاً لكن بندم مستمرّ. النتيجة: بسيط وفعّال. الربط بالذكاء الاصطناعي: خطّ أساس شائع.

مثال (25.6-6): UCB وتقليل الندم المعطيات: نستخدم UCB. المطلوب: الحدّ. الحل: الخطوة 1: $O(\sqrt{T \log T})$ (أو $O(\log T)$ في إعدادات). النتيجة: ضمان قويّ. الربط بالذكاء الاصطناعي: اختيار مدعوم نظريّاً.

مثال (25.6-7): عيّنة طومسون مجدّداً المعطيات: بديل بايزي. المطلوب: الأداء. الحل: الخطوة 1: أداء عملي ممتاز وندم جيد. النتيجة: شيوعها في الصناعة. الربط بالذكاء الاصطناعي: A/B تكيّفي.

مثال (25.6-8): السياقية المعطيات: نعرف سياقاً قبل القرار. المطلوب: التعميم. الحل: الخطوة 1: bandit سياقية $\Rightarrow$ نربط القرار بالميزات. النتيجة: يقرّبنا من RL (الفصل 44). الربط بالذكاء الاصطناعي: توصية/إعلانات.

مثال (25.6-9): العلاقة بـ BO المعطيات: BO المتّصل. المطلوب: الرابط. الحل: الخطوة 1: BO هي bandit على فضاء متّصل بنموذج GP. النتيجة: توحيد المفاهيم. الربط بالذكاء الاصطناعي: ربط النظريات.

مثال (25.6-10): الندم البسيط مقابل التراكمي المعطيات: نهتم بالأخيرة فقط. المطلوب: الفرق. الحل: الخطوة 1: الندم البسيط = جودة الحلّ النهائي؛ التراكمي = تكلفة الرحلة. النتيجة: معياران مختلفان. الربط بالذكاء الاصطناعي: حسب الهدف.

مثال (25.6-11): الحدّ الأدنى المعطيات: هل يمكن أفضل؟ المطلوب: الحكم. الحل: الخطوة 1: حدود سفلية معلومة $\Rightarrow$ لا نتجاوزها. النتيجة: تقييم الخوارزميات. الربط بالذكاء الاصطناعي: حدود النظرية.

مثال (25.6-12): التطبيق على التوصية المعطيات: نعرض عناصر للمستخدمين. المطلوب: النموذج. الحل: الخطوة 1: كلّ عنصر ذراع؛ النقر عائد. النتيجة: تعلّم تكيّفي. الربط بالذكاء الاصطناعي: أنظمة التوصية.

مثال (25.6-13): المفاضلة بالأرقام المعطيات: ذراعان بمتوسطين 8.0 و 6.0. المطلوب: استراتيجية. الحل: الخطوة 1: UCB يختار الثاني أحياناً حتى يتأكّد. النتيجة: استكشاف مبرّر. الربط بالذكاء الاصطناعي: قرارات الاستكشاف.

مثال (25.6-14): التوقف المعطيات: متى نتوقّف عن الاستكشاف؟ المطلوب: القاعدة. الحل: الخطوة 1: حين يصير عدم اليقين أقلّ من فرق المتوسطات. النتيجة: استغلال نهائي. الربط بالذكاء الاصطناعي: إنهاء التجارب.

مثال (25.6-15): خلاصة الإطار المعطيات: كلّ ما سبق. المطلوب: القيمة. الحل: الخطوة 1: الندم يحوّل «الاستكشاف» إلى مقياس قابل للتحليل. النتيجة: أداة نظرية مركزية. الربط بالذكاء الاصطناعي: تحليل الخوارزميات.

أخطاء شائعة

- قياس الجودة بالخطوة الأخيرة فقط.
- استخدام استراتيجية جشعة خالصة.
- نسيان أنّ الاستكشاف له تكلفة تُحسب في الندم.
- الخلط بين bandit و RL الكامل (لا انتقال حالات هنا).

في تدريب موزّع، يحسب كلّ عامل تدرّجاً على دفعته ثمّ تُجمَع:

$$g = \frac{1}{K}\sum_{k=1}^{K} g_k, \qquad x_{t+1} = x_t - \eta\, g \quad \text{(توازي بيانات / AllReduce)} \tag{6.25}$$

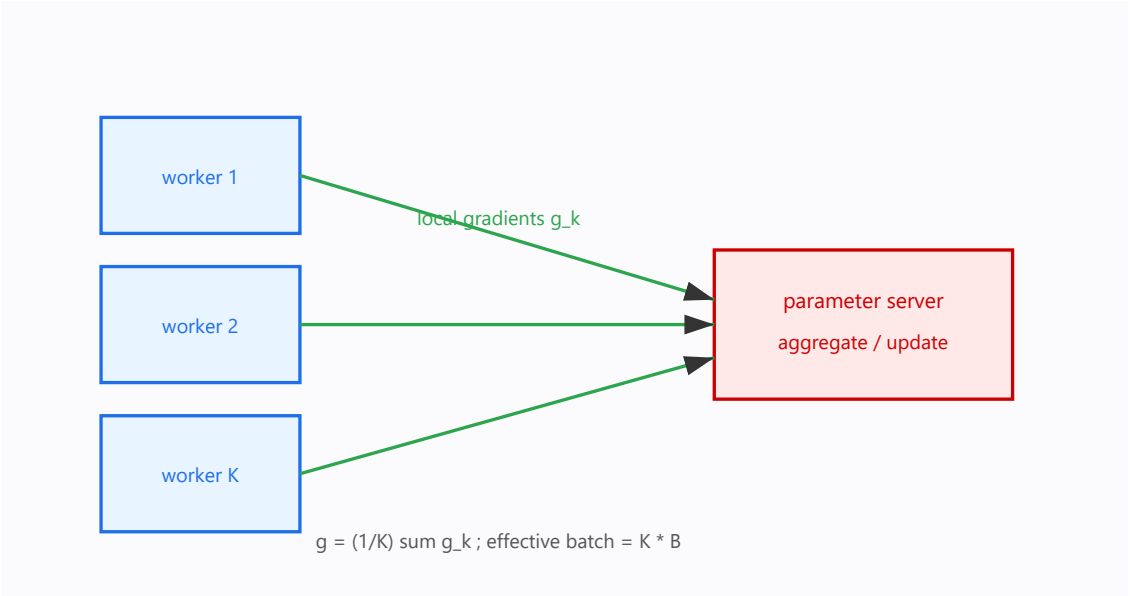
أو يُحدَّث معلّم مركزي عند استلام التدرّجات (معلّم العاملات).

جدول الرمز

الرمز	المعنى
K	عدد العُقد
g_k	التدرّج المحلي على العقدة k
AllReduce	تجميع كفء
متزامن/غير متزامن	توقيت التحديث

الرسم

<figure> الشكل<figcaption> 6.25: كلّ عقدة تحسب تدرّجاً محلياً؛ التجميع يعطي تدرّجاً مكافئاً لدفعة أكبر.</figcaption> </figure>



شكل ٦.٢٥: *
التحسين التوزيعي: توازي البيانات ومعلم العاملات

البرهان (مخطّط)

بخطّية التدرّج واستقلال العيّنات، $\frac{1}{K}\sum_k g_k$ هو تقدير غير متحيّز للتدرّج على دفعة بحجم KB؛ وبالتجميع المتزامن يبقى التحديث مطابقاً لـ SGD بدفعة كبيرة. ■

خمسة عشر مثالاً محلولاً

مثال (25.7-1): الدفعة الفعّالة المعطيات: 8 عُقد بدفعة 32 لكلّ منها. المطلوب: الدفعة الفعّالة. الحل: الخطوة 1: $8 \times 32 = 256$. النتيجة: 256. الربط بالذكاء الاصطناعي: تدريب محوّلات ضخمة.

مثال (25.7-2): التجميع المعطيات: 4 تدرّجات محلية. المطلوب: التحديث. الحل: الخطوة 1: نأخذ المتوسط ثمّ نطبّق المحسّن. النتيجة: تحديث متزامن. الربط بالذكاء الاصطناعي: AllReduce في المكتبات.

مثال (25.7-3): التسريع المتوقّع المعطيات: 8 عُقد. المطلوب: التسريع المثالي. الحل: الخطوة 1: 8 أضعاف نظرياً؛ أقلّ فعلياً بسبب الاتصال. النتيجة: كفاءة توسّع. الربط بالذكاء الاصطناعي: اقتصاد التدريب.

مثال (25.7-4): عنق زجاجة الاتصال المعطيات: نموذج بمليارات المعاملات. المطلوب: المشكلة. الحل: الخطوة 1: إرسال التدرّجات يهيمن على الوقت. النتيجة: نضغط/نقلل الاتصال. الربط بالذكاء الاصطناعي: تدريب موزّع فعّال.

مثال (25.7-5): التدرّج التراكمي محلياً المعطيات: اتصال بطيء. المطلوب: الحلّ. الحل: الخطوة 1: نجمع عدّة خطوات محليّة قبل التجميع. النتيجة: اتصال أقلّ. الربط بالذكاء الاصطناعي: تدريب بعرض نطاق محدود.

مثال (25.7-6): التزامن مقابل عدمه المعطيات: عُقد بسرعات مختلفة. المطلوب: المقايضة. الحل: الخطوة 1: المتزامن أدقّ لكن ينتظر الأبطأ؛ غير المتزامن أسرع لكن بتدرّجات قديمة. النتيجة: مفاضلة معروفة. الربط بالذكاء الاصطناعي: هندسة التدريب.

مثال (25.7-7): التدرّجات القديمة (stale) المعطيات: تحديث بتدرّج من خطوة سابقة. المطلوب: الأثر. الحل: الخطوة 1: يضيف ضجيجاً/انحيازاً؛ نحدّد «عمراً» أقصى. النتيجة: استقرار مقبول. الربط بالذكاء الاصطناعي: تدريب غير متزامن.

مثال (25.7-8): معلّم العاملات المعطيات: بنية مركزية. المطلوب: الدور. الحل: الخطوة 1: يحتفظ بالمعاملات ويطبّق التحديثات الواردة. النتيجة: فصل الحساب عن الحالة. الربط بالذكاء الاصطناعي: بنى تدريب واسعة.

مثال (25.7-9): توازي النموذج المعطيات: نموذج أكبر من ذاكرة عقدة. المطلوب: الحلّ. الحل: الخطوة 1: نقسّم النموذج بين العُقد (tensor/pipeline parallelism). النتيجة: تدريب نماذج ضخمة. الربط بالذكاء الاصطناعي: تدريب LLMs.

مثال (25.7-10): ضبط معدّل التعلّم الموزّع المعطيات: نكبّر الدفعة الفعّالة. المطلوب: التعديل. الحل: الخطوة 1: نكبّر η (قاعدة القياس الخطّي) مع تسخين. النتيجة: تدريب مستقرّ. الربط بالذكاء الاصطناعي: تدريب بدفعات كبيرة.

مثال (25.7-11): قصّ التدرّج الموزّع المعطيات: انفجار التدرّجات. المطلوب: التنفيذ. الحل: الخطوة 1: نحسب النُرم عالمياً (بعد AllReduce) ثمّ نقصّ. النتيجة: استقرار متسق. الربط بالذكاء الاصطناعي: تدريب النماذج الضخمة.

مثال (25.7-12): التطبيع بالدفعات الموزّع المعطيات: إحصاءات محلية مختلفة. المطلوب: المعالجة. الحل: الخطوة 1: نزامن الإحصاءات عبر العُقد (SyncBN). النتيجة: طبقات معيارية صحيحة. الربط بالذكاء الاصطناعي: تدريب رؤية موزّع.

مثال (25.7-13): نقاط التفتيش المعطيات: تدريب طويل. المطلوب: الأمان. الحل: الخطوة 1: نحفظ الحالة دورياً للاستئناف بعد الفشل. النتيجة: موثوقية. الربط بالذكاء الاصطناعي: بنية تحتية للتدريب.

مثال (25.7-14): التكلفة مقابل الفائدة المعطيات: هل نوزّع دائماً؟ المطلوب: الحكم. الحل: الخطوة 1: التوزيع يفيد حين يكون الحساب هو العنق لا الاتصال. النتيجة: قرار هندسي. الربط بالذكاء الاصطناعي: اقتصاد التدريب.

مثال (25.7-15): خلاصة التوزيع المعطيات: كلّ التقنيات. المطلوب: الصورة. الحل: الخطوة 1: توزيع البيانات + النموذج + تقليل الاتصال = تدريب واسع. النتيجة: إطار موحّد. الربط بالذكاء الاصطناعي: تدريب النماذج الضخمة.

أخطاء شائعة

- تجاهل تكلفة الاتصال في حساب التسريع.
- ترك معدّل التعلّم بلا تعديل عند تكبير الدفعة.
- قصّ التدرّج محليّاً فقط بدل عالميّاً.
- افتراض تسريع خطّي بلا حساب التزامن.

FedAvg يدمج النماذج المحلية بمتوسط مرجّح بعدد العيّنات:

$$w_{t+1} = \sum_{k=1}^{K} \frac{n_k}{n} w_{t+1}^{(k)}, \qquad n = \sum_k n_k \tag{7.25}$$

فلا تُجمع البيانات الخام مركزيّاً، بل تُجمع المعاملات فقط.

جدول الرموز

الرمز	المعنى
$w^{(k)}$	نموذج العقدة/العميل k
n_k	عدد عيّنات العميل
n	الإجمالي
جولات	دورات التواصل

الرسم

<figure> الشكل<figcaption> 7.25: العملاء يتعلّمون محليّاً، ثمّ تُدمَج النماذج بمتوسط مرجّح مركزيّاً.</figcaption>
</figure>

البرهان (مخطّط)

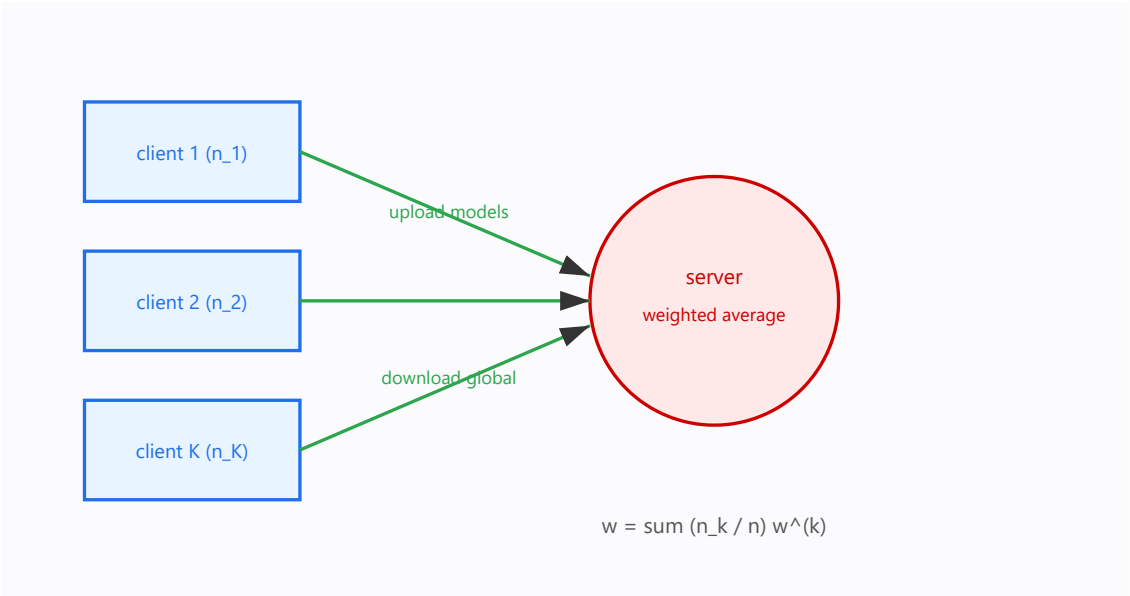
بمتوسط النماذج المدرّبة على بيانات مستقلّة غير متطابقة، يعطي المتوسط المرجّح تقديراً يقلّل التباين ويبقى قريباً من الحلّ المركزي؛ وبتكرار الجولات يتقارب (مع تدرّج انحراف العميل). ■

خمسة عشر مثالاً محلولاً

مثال (25.8-1): حساب المتوسط المعطيات: عميلان، $n_1 = 900$، $n_2 = 100$. المطلوب: الأوزان. الحل: الخطوة 1: 0.9 و 0.1. النتيجة: الأكبر يهيمن. الربط بالذكاء الاصطناعي: دمج نماذج متفاوتة البيانات.

مثال (25.8-2): لماذا نماذج لا بيانات؟ المعطيات: خصوصية المستخدمين. المطلوب: المبرّر. الحل: الخطوة 1: مشاركة المعاملات أقلّ كشفاً من البيانات الخام. النتيجة: تعلّم يحترم الخصوصية. الربط بالذكاء الاصطناعي: التعلّم الاتحادي.

مثال (25.8-3): عدد الجولات المعطيات: 100 جولة اتصال. المطلوب: المقارنة بالمركزي. الحل: الخطوة 1: الاتحادي يحتاج جولات أكثر لكن يحفظ الخصوصية. النتيجة: مفاضلة. الربط بالذكاء الاصطناعي: ميزانية الاتصال.



شكل ٧.٢٥: *
متوسط النماذج والتعلم الاتحادي

مثال (25.8-4): البيانات غير المتطابقة المعطيات: عملاء بتوزيعات مختلفة. المطلوب: المشكلة. الحل: الخطوة 1: «انحراف العميل» يبطئ التقارب ويحيّز المتوسط. النتيجة: نحتاج تقنيات (مثل FedProx). الربط بالذكاء الاصطناعي: learning. federated non-IID

مثال (25.8-5): الخطوات المحلية المعطيات: E عصور محلية قبل الدمج. المطلوب: الأثر. الحل: الخطوة 1: تقلّل الاتصال لكن تزيد الانحراف. النتيجة: مفاضلة معروفة. الربط بالذكاء الاصطناعي: ضبط FedAvg.

مثال (25.8-6): الأمان المعطيات: معاملات مشتركة. المطلوب: الخطر. الحل: الخطوة 1: قد تُستنتج بيانات من التدرّجات (هجوم استدلال). النتيجة: نضيف خصوصية تفاضلية/تشفيراً. الربط بالذكاء الاصطناعي: أمن التعلّم الاتحادي.

مثال (25.8-7): الخصوصية التفاضلية المعطيات: نريد ضماناً. المطلوب: الطريقة. الحل: الخطوة 1: نضيف ضجيجاً ونقصّ النُرم قبل المشاركة. النتيجة: ضمان رياضي. الربط بالذكاء الاصطناعي: DP في التعلّم.

مثال (25.8-8): التجميع الآمن المعطيات: خادم قد يطّلع. المطلوب: الحلّ. الحل: الخطوة 1: تجميع آمن (secure aggregation) فلا يرى الخادم المساهمات الفردية. النتيجة: خصوصية أقوى. الربط بالذكاء الاصطناعي: بروتوكولات تشفيرية.

مثال (25.8-9): متوسط النماذج التقليدي المعطيات: عدّة نماذج مستقلّة. المطلوب: الفائدة. الحل: الخطوة 1: يقلّل التباين ويحسّن التعميم (من 30). النتيجة: تجميع بسيط وفعّال. الربط بالذكاء الاصطناعي: model soups/ensembles.

مثال (25.8-10): EMA للأوزان المعطيات: تدريب طويل. المطلوب: الاستخدام. الحل: الخطوة 1: متوسط أُسّي متحرّك للأوزان ⇒ حلول أكثر استقراراً. النتيجة: تحسين معايرة. الربط بالذكاء الاصطناعي: EMA/SWA.

مثال (25.8-11): التخصيص الشخصي المعطيات: نموذج عامّ لا يصلح لكلّ عميل. المطلوب: الحلّ. الحل: الخطوة 1: نضبط محلياً بعد الدمج (fine-tuning شخصي). النتيجة: تعلّم اتحادي مخصّص. الربط بالذكاء الاصطناعي: personalization.

مثال (25.8-12): الاتصال الجزئي المعطيات: آلاف العملاء. المطلوب: الكفاءة. الحل: الخطوة 1: نختار عيّنة من العملاء كلّ جولة. النتيجة: توفير كبير. الربط بالذكاء الاصطناعي: تدريب اتحادي واسع.

مثال (25.8-13): التطبيق على الأجهزة المعطيات: هواتف بموارد محدودة. المطلوب: التحديات. الحل: الخطوة 1:

اتصال متقطّع وطاقة محدودة ⇒ تحديثات نادرة. النتيجة: قيود التصميم. الربط بالذكاء الاصطناعي: تعلّم على الحافة.

مثال (25.8-14): مقارنة بالموزّع الكلاسيكي المعطيات: مركز بيانات مقابل هواتف. المطلوب: الفرق. الحل: الخطوة 1: الموزّع يتحكّم بالبيانات، الاتحادي لا يملكها. النتيجة: إطاران مختلفان. الربط بالذكاء الاصطناعي: اختيار البنية.

مثال (25.8-15): خاتمة الجزء المعطيات: كلّ الجزء الرابع. المطلوب: الصورة. الحل: الخطوة 1: من شروط الأمثلية (20) إلى القيود (21) والتحدّب (22) والمحسّنات (23) والهندسة (24) وصولاً إلى غياب التدرّج وكثرة الآلات (25). النتيجة: اكتمال أدوات التحسين. الربط بالذكاء الاصطناعي: الانتقال للجزء الخامس (نظرية المعلومات).

أخطاء شائعة

- تجاهل انحراف العميل في البيانات غير المتطابقة.
- افتراض أنّ مشاركة المعاملات آمنة تماماً.
- متوسط غير مرجّح فيعملاء متفاوتو الحجم.
- كثرة الخطوات المحلية بلا ضبط فتتباعد النماذج.

ملخّص النظريات

النظرية	المفهوم	التطبيق
25.2 الأسود	بلا تدرّج بميزانية	HPO و NAS
GP 25.3	خلفيان μ_t, σ_t	نموذج بديل
EI 25.4	$\mathbb{E}[\max(0, f^\star - f)]$	اختيار النقطة التالية
UCB/PI 25.5	$\Phi(z)$ / $\mu + \kappa\sigma$	بدائل الاكتساب
25.6 الندم	$R_T = O(\sqrt{T \log T})$	قياس القرار المتسلسل
25.7 التوزيعي	$g = \frac{1}{K}\sum g_k$	تدريب واسع النطاق
25.8 الاتحادي	$w = \sum \frac{n_k}{n} w^{(k)}$	تعلّم بلا مركزية بيانات

عشرون تمريناً (مع إجابات مختصرة)

١. ما التحسين الأسود؟ (بلا تدرّج، تقييم مكلف)

٢. لماذا البحث الشبكي ضعيف؟ (لعنة الأبعاد)

٣. ماذا تعطي GP؟ (μ_t و σ_t)

٤. تكلفة GP مع t نقطة؟ ($O(t^3)$)

٥. صيغة EI؟ ($(f^\star - \mu)\Phi(z) + \sigma\phi(z)$)

٦. ما z في EI؟ ($\frac{f^\star - \mu}{\sigma}$)

٧. ماذا يحدث لـ EI عند $\sigma \to 0$؟ (تقترب من صفر إن لم تكن واعدة)

٨. صيغة UCB؟ ($\mu + \kappa\sigma$)

٩. PI تحسب ماذا؟ (احتمال التحسين $\Phi(z)$)

١٠. عيب PI؟ (لا تراعي مقدار التحسين)

١١. تعريف الندم؟ ($\sum(f^\star - f(x_t))$)

١٢. لماذا نريد ندماً دون خطّي؟ ($R_T/T \to 0 \Rightarrow$ تعلّم)

١٣. الدفعة الفعّالة بـ K عُقد؟ (KB)

١٤. مشكلة التزامن؟ (انتظار الأبطأ)

١٥. مشكلة عدم التزامن؟ (تدرّجات قديمة)

١٦. صيغة FedAvg؟ ($w = \sum \frac{n_k}{n} w^{(k)}$)

١٧. مشكلة non-IID؟ (انحراف العميل)

١٨. كيف نحمي الخصوصية؟ (خصوصية تفاضلية/تجميع آمن)

١٩. لماذا نماذج لا بيانات؟ (خصوصية وتكلفة اتصال)

٢٠. متى BO لا يناسب؟ (أبعاد عالية جدّاً)

فهرس الرموز

الرمز	المعنى
$\mathcal{D}_t$	تاريخ التقييمات
μ_t, σ_t	المتوسط والانحراف الخلفيّان
$\alpha_{\text{EI}}, \alpha_{\text{UCB}}, \alpha_{\text{PI}}$	دوالّ الاكتساب
R_T	الندم التراكمي
K, n_k	عدد العُقد وعيّنات العميل

مراجع

- Shahriari et al. — «Taking the Human Out of the Loop: A Review of Bayesian Optimization».
- Rasmussen & Williams — *Gaussian Processes for Machine Learning*.
- Snoek, Larochelle & Adams — «Practical Bayesian Optimization of Machine Learning Algorithms».
- Auer, Cesa-Bianchi & Fischer — «Finite-time Analysis of the Multiarmed Bandit Problem».
- Li et al. — «Communication-Efficient Learning of Deep Networks from Decentralized Data (FedAvg)».
- Dean et al. — «Large Scale Distributed Deep Networks».

خاتمة الجزء الرابع — التحسين

<

اكتمل الآن الجزء الرابع بفصوله الستّة: - **20** شروط الأمثلية غير المقيّدة، - **21** القيود و KKT والثنائية، - **22** التحليل المحدّب والازدواج المترافق، - **23** المحسّنات العشوائية SGD) إلى ،(Adam - **24** التحسين على المتشعّبات، - **25** التحسين الأسود والتوزيعي.

<

نملك الآن لغة كاملة للإجابة عن «كيف نجد الحلّ؟». الجزء الخامس ينتقل إلى سؤال مختلف: «**كم نعرف؟**» — نظرية المعلومات، من الإنتروبيا (26) إلى تباعد KL (27) والترميز (28) والهندسة المعلوماتية (29).

القسم V

نظرية المعلومات

نبذة عن هذا الجزء

ما هي «المعلومة»؟ جرى هذا السؤال جريلاً في كل جزء سابق بلا تعريف صارم. هنا يُعرَّف عدّه: **إنتروبيا شانون** كمقياس عدم التأكّد، **والمعلومات المتبادلة** كمقياس ما تشرحه متغيّرات في بعضها، **والإنتروبيا المتقاطعة والتباعد KL** بوصفهما دوالّ الخسارة الكونيّة في التعلّم العميق، ثم تعميمات **التباعد-f** العائليّة. بعدها نحوّل المفاهيم إلى أرقامٍ قابلة للتحصيل: **سعة القناة** وحدود **الترميز والضغط** ومبدأ **الطول الوصفي الأدنى MDL** الذي يوازن النموذج مع بياناته. ونختم بالتاج الرياضي للجزء: **الهندسة المعلوماتية** حيث عائلة التوزيعات تصير متعدّد شعب ومقياس فيشر يصير المسافة، فيتحوّل انحدار التدرّج الطبيعي إلى أبسط صيغه الهندسية. هذا الجزء هو الميزان الذي نزن به كل ما يليه: من حدود التعميم إلى النماذج التوليدية.

فصول الجزء: الإنتروبيا والمعلومات المتبادلة · الإنتروبيا المتقاطعة والتباعدات · سعة القناة والترميز وMDL · الهندسة المعلوماتية ومقياس فيشر.

فصول هذا الجزء

- **الفصل 26.** الإنتروبيا، الإنتروبيا المشتركة، وكسب المعلومات
- **الفصل 27.** إنتروبيا التقاطع، تباعد KL، وتباعدات ف-ديفرجنس
- **الفصل 28.** السعة، الترميز، ومبدأ الوصف الأقصر
- **الفصل 29.** الهندسة المعلوماتية وقياس فيشر

الإنتروبيا، الإنتروبيا المشتركة، وكسب المعلومات

«المعلومات هي ما يقلّل المفاجأة؛ والإنتروبيا مقياس تلك المفاجأة.»

بهذا الفصل نفتتح **الجزء الخامس (نظرية المعلومات)**. بعد أن بنينا الاحتمالات (الجزء الثالث) والتحسين (الجزء الرابع)، ننتقل إلى سؤال مختلف: **كم نعرف؟** لا «كيف نحسّن؟». نظرية المعلومات هي اللغة التي تشرح لماذا تعمل الإنتروبيا المتقاطعة كخسارة، ولماذا تختار أشجار القرار أفضل سؤال، ولماذا softmax هو الخيار الأقلّ التزاماً. سبع نظريات:

- **2.26 إنتروبيا شانون** — مقياس المفاجأة المتوقّعة.
- **3.26 الإنتروبيا المشتركة والشرطية** — وقاعدة السلسلة.
- **4.26 المعلومات المتبادلة** — كم يخبرنا متغيّر عن آخر؟
- **5.26 خصائص الإنتروبيا** — الحدّ الأقصى، التقعّر، والتخفيض بالتكييف.
- **6.26 الإنتروبيا التفاضلية** — المتغيّرات المستمرّة.
- **7.26 كسب المعلومات وأشجار القرار** — الاختيار الأذكى للسؤال.
- **8.26 مبدأ الإنتروبيا الأعظمية** — softmax والتوزيعات الأسّية.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى
X, Y	متغيّران عشوائيّان
$p(x)$	توزيع الاحتمال
$H(X)$	الإنتروبيا
$H(Y \mid X)$	الإنتروبيا الشرطية
$I(X;Y)$	المعلومات المتبادلة
$h(X)$	الإنتروبيا التفاضلية
$\log$	اللوغاريتم (أساس 2 ⇒ بت، طبيعي ⇒ نات)

نلتزم بالأساس 2 في الأمثلة (بتّات)، ونذكر «نات» عند اللزوم.

لمتغيّر منفصل X بقيم في $\mathcal{X}$ وتوزيع p:

$$H(X) \;=\; -\sum_{x \in \mathcal{X}} p(x)\,\log p(x) \;=\; \mathbb{E}\left[\log \frac{1}{p(X)}\right] \tag{1.26}$$

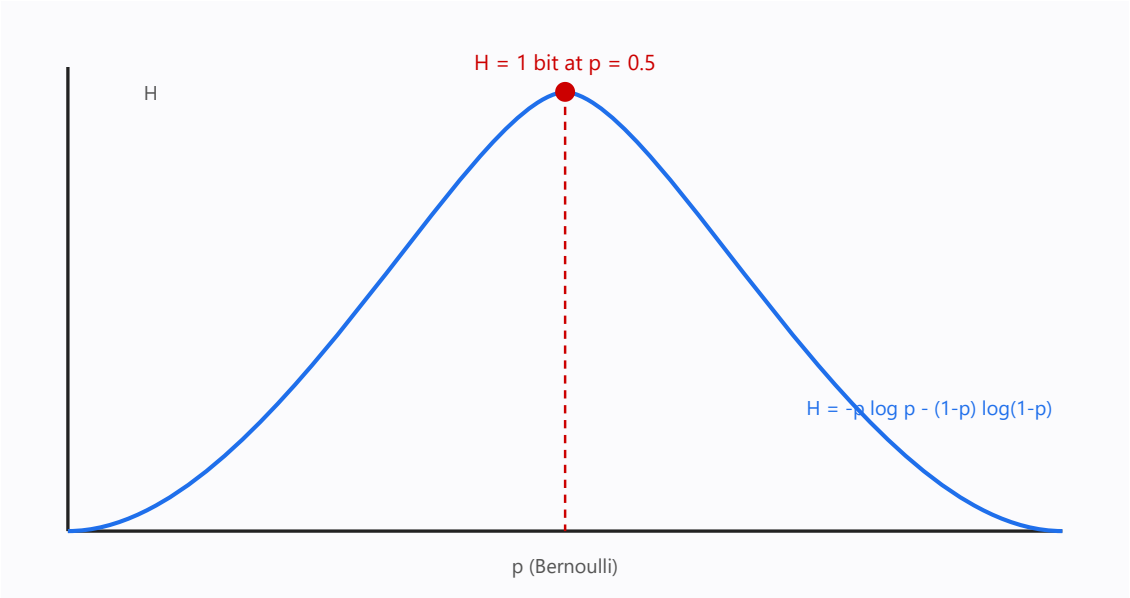
وهي «متوسّط المفاجأة» أو الحدّ الأدنى لطول الترميز المتوقّع.

جدول الرموز

الرمز	المعنى
$H(X)$	الإنتروبيا (بتّات إن كان الأساس 2)
$\log \frac{1}{p(x)}$	مفاجأة الحدث x
$p \log p$	باتفاق $0 \log 0 = 0$
$\mathbb{E}$	التوقّع (من 15)

الرسم

<figure> الشكل<figcaption> 1.26: إنتروبيا برنولي تبلغ ذروتها 1 بت عند $p = 0.5$ وتصفُر عند



شكل ١.٢٦: *
إنتروبيا شانون: أقصى قيمة عند التوزيع المنتظم

الطرفين.</figcaption> </figure>

البرهان (مخطّط)

نطلب مقياساً H متّصلاً، رتيباً في عدد النتائج المتساوية، ومجمعاً (additive) للأحداث المستقلّة؛ شانون أثبت أنّ الصيغة الوحيدة (حتى ثابت) هي (1.26). ■

خمسة عشر مثالاً محلولاً

مثال (1-2.26): قطعة نقد عادلة المعطيات: $P(H) = P(T) = 0.5$. المطلوب: H. الحل: الخطوة 1: $H = -2 \times 0.5 \log_2 0.5 = -2 \times 0.5 \times (-1) = 1$. النتيجة: 1 بت. الربط بالذكاء الاصطناعي: بتّ واحد يفصل بين احتمالين متساويين.

مثال (2-2.26): قطعة منحازة المعطيات: $p = 0.9$. المطلوب: H. الحل: الخطوة 1: $H = -0.9 \log_2 0.9 - 0.1 \log_2 0.1$. الخطوة 2: $= 0.9(0.152) + 0.1(3.322) = 0.137 + 0.332 = 0.469$ بت. النتيجة: ≈ 0.469. الربط بالذكاء الاصطناعي: نموذج واثق جدّاً $\Rightarrow$ إنتروبيا منخفضة.

مثال (3-2.26): حدث مؤكّد المعطيات: $p = 1$. المطلوب: H. الحل: الخطوة 1: $-1 \log_2 1 - 0 \log_2 0 = 0$. النتيجة: 0 بت (لا مفاجأة). الربط بالذكاء الاصطناعي: تنبّؤ حتمي بلا uncertainty.

مثال (4-2.26): نرد عادل المعطيات: 6 أوجه متساوية. المطلوب: H. الحل: الخطوة 1: $\log_2 6 \approx 2.585$. النتيجة: 585.2 بت. الربط بالذكاء الاصطناعي: أقصى إنتروبيا لـ 6 فئات.

مثال (5-2.26): الوحدات المعطيات: نستخدم ln بدل $\log_2$. المطلوب: الوحدة. الحل: الخطوة 1: $1 \text{ nat} = \log_2 e \approx 1.443$ bit (nats)؛ النتيجة: تحويل بعامل ثابت. الربط بالذكاء الاصطناعي: مكتبات التعلّم تستخدم النات طبيعيّاً.

مثال (6-2.26): مصدر حتمي المعطيات: متغيّر ثابت القيمة. المطلوب: H. الحل: الخطوة 1: التوزيع متدهور $\Rightarrow H = 0$. النتيجة: لا معلومات. الربط بالذكاء الاصطناعي: ميزة ثابتة لا تفيد النموذج.

مثال (7-2.26): المنتظم أعظمي المعطيات: 4 قيم. المطلوب: أقصى H. الحل: الخطوة 1: عند المنتظم $H = \log_2 4 = 2$. النتيجة: 2 بت. الربط بالذكاء الاصطناعي: تهيئة softmax متساوية = أقصى إنتروبيا.

مثال (8-2.26): بايت منتظم المعطيات: 256 قيمة متساوية. المطلوب: H. الحل: الخطوة 1: $\log_2 256 = 8$. النتيجة: 8 بتّات. الربط بالذكاء الاصطناعي: ضغط البيانات يهدف للاقتراب من الإنتروبيا.

مثال (9-2.26): نصّ لغوي المعطيات: لغة إنجليزية ≈ 3.1 بت/حرف. المطلوب: التفسير. الحل: الخطوة 1: أقلّ من $\log_2 26 \approx 4.7$ بسبب التكرار والقيود. النتيجة: الإنتروبيا تقيس «المحتوى الحقيقي». الربط بالذكاء الاصطناعي: نماذج اللغة تضغط اللغة (الفصل 28).

مثال (10-2.26): إنتروبيا مخرجات المصنّف المعطيات: softmax بـ $(0.98, 0.01, 0.01)$. المطلوب: H. الحل: الخطوة 1: $-0.98 \log_2 0.98 - 2(0.01 \log_2 0.01) \approx 0.0285 + 0.1328 = 0.161$ بت. النتيجة: ≈ 161.0 بت (واثق). الربط بالذكاء الاصطناعي: إنتروبيا منخفضة $\Rightarrow$ ثقة عالية.

مثال (11-2.26): طول الترميز المعطيات: إنتروبيا 585.2 بت للنرد. المطلوب: العلاقة. الحل: الخطوة 1: الحدّ الأدنى لطول الترميز المتوقّع $\approx$ الإنتروبيا (الفصل 28). النتيجة: الإنتروبيا = حدّ الضغط. الربط بالذكاء الاصطناعي: ضغط النماذج و MDL.

مثال (12-2.26): برنولي متطرّف المعطيات: $p = 0.99$. المطلوب: H. الحل: الخطوة 1: $-0.99 \log_2 0.99 - 0.01 \log_2 0.01 \approx 0.0144 + 0.0664 = 0.0808$. النتيجة: ≈ 081.0 بت. الربط بالذكاء الاصطناعي: أحداث نادرة قابلة للتنبّؤ بشدة.

مثال (13-2.26): 10 فئات المعطيات: منتظم على 10. المطلوب: H. الحل: الخطوة 1: $\log_2 10 \approx 3.322$. النتيجة: 322.3 بت. الربط بالذكاء الاصطناعي: ImageNet بـ 1000 فئة $\Rightarrow$ حتى 97.9 بت.

مثال (14-2.26): الإنتروبيا كمفاجأة متوقّعة المعطيات: $\mathbb{E}[\log \frac{1}{p(X)}]$. المطلوب: التفسير. الحل: الخطوة 1: كلّ حدث «يكلف» $-\log p$؛ المتوسط هو الإنتروبيا. النتيجة: قراءة حدسية مباشرة. الربط بالذكاء الاصطناعي: خسارة السجلّ السالب = مفاجأة العيّنة.

مثال (15-2.26): إنتروبيا كلمة سرّ المعطيات: 8 حروف من 62 رمزاً منتظماً. المطلوب: الإنتروبيا. الحل: الخطوة 1: $8 \log_2 62 \approx 8(5.954) = 47.6$ بت. النتيجة: ≈ 6.47 بت. الربط بالذكاء الاصطناعي: قوة الأسر تقاس بالإنتروبيا (الأمن السيبراني).

أخطاء شائعة

- نسيان الاتفاق $0 \log 0 = 0$ فتظهر «ليس رقم».
- الخلط بين البتّ والنات.
- افتراض أنّ إنتروبيا أعلى «أفضل» دائماً (في المصنّف تعني شكّاً).
- حساب الإنتروبيا على عدّادات غير مطبّعة.

$$H(X,Y) = -\sum_{x,y} p(x,y)\log p(x,y), \qquad H(Y\mid X) = -\sum_{x} p(x)\sum_{y} p(y\mid x)\log p(y\mid x) \tag{2.26}$$

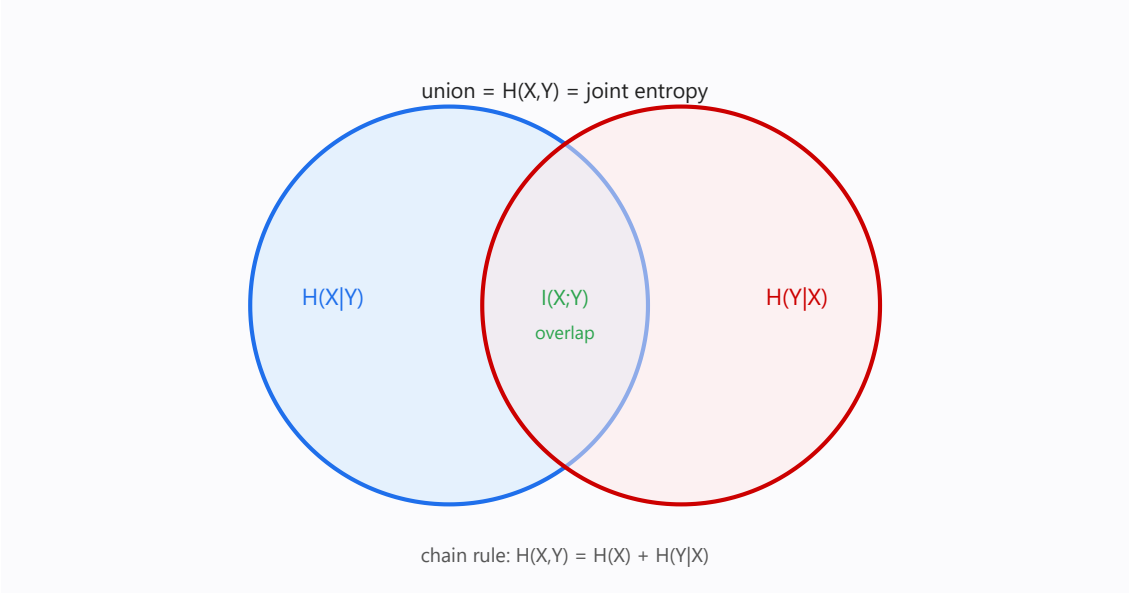
قاعدة السلسلة: $H(X,Y) = H(X) + H(Y\mid X) = H(Y) + H(X\mid Y)$.

جدول الرموز

الرمز	المعنى
$H(X,Y)$	الإنتروبيا المشتركة
$H(Y\mid X)$	إنتروبيا Y بعد معرفة X
$p(y\mid x)$	التوزيع الشرطي (من 16)
استقلال	$H(X,Y) = H(X) + H(Y)$

الرسم

<figure> الشكل<figcaption> 2.26: دائرتان متداخلتان: الاتحاد $H(X,Y)$، والقسم غير المشترك هو الإنتروبيا



شكل ٢.٢٦: *
الإنتروبيا المشتركة والشرطية

الشرطية.</figcaption> </figure>

البرهان (مخطّط)

نفكّك $p(x,y) = p(x)p(y\mid x)$ فنحصل على $-\sum p(x,y)[\log p(x) + \log p(y\mid x)] = H(X) + H(Y\mid X)$ بمبرهنة التوقّع الكلّي (من 3.15). ■

خمسة عشر مثالاً محلولاً

مثال (1-3.26): الحساب المشترك المعطيات: 4 أزواج باحتمال $\frac{1}{4}$ لكلّ. المطلوب: $H(X,Y)$. الحل: الخطوة 1: $\log_2 4 = 2$. النتيجة: 2 بت. الربط بالذكاء الاصطناعي: ترميز الأزواج يحتاج بتّين.

مثال (26.3-2): قاعدة السلسلة المعطيات: $H(X) = 1$، $H(Y \mid X) = 0.5$. المطلوب: $H(X,Y)$. الحل: الخطوة 1: $1 + 0.5 = 1.5$. النتيجة: 1.5 بت. الربط بالذكاء الاصطناعي: ترميز متسلسل للمتغيّرات.

مثال (26.3-3): الاستقلال المعطيات: $X \perp Y$ بـ $H(X) = 1$، $H(Y) = 2$. المطلوب: $H(X,Y)$. الحل: الخطوة 1: $H = 1 + 2 = 3 \Rightarrow H(Y \mid X) = H(Y) = 2$. النتيجة: 3 بتّات. الربط بالذكاء الاصطناعي: ميزتان مستقلّتان تضيفان معلومات.

مثال (26.3-4): الشرطية المعطيات: $H(X,Y) = 2.5$، $H(X) = 1.5$. المطلوب: $H(Y \mid X)$. الحل: الخطوة 1: $2.5 - 1.5 = 1$. النتيجة: 1 بت. الربط بالذكاء الاصطناعي: عدم يقين متبقٍ بعد الميزة.

مثال (26.3-5): التكييف يقلّل الإنتروبيا المعطيات: أيّ X, Y. المطلوب: المتراجحة. الحل: الخطوة 1: $H(Y \mid X) \leq H(Y)$ (انظر 5.26). النتيجة: المعلومات لا تضرّ. الربط بالذكاء الاصطناعي: كلّ ميزة تقلّل الشكّ (أو لا تغيّره).

مثال (26.3-6): مثال الطقس المعطيات: X=مطر، Y=مظلّة. المطلوب: التفسير. الحل: الخطوة 1: معرفة المطر تقلّل عدم يقين المظلّة كثيراً. النتيجة: $H(Y \mid X) \ll H(Y)$. الربط بالذكاء الاصطناعي: ميزة قوية predictive.

مثال (26.3-7): حساب جدولي المعطيات: جدول $p(x,y)$. المطلوب: الطريقة. الحل: الخطوة 1: نحسب $H(X,Y)$ من الجدول، ثمّ $H(X)$ من الهامش، ثمّ الفرق. النتيجة: إنتروبيا شرطية. الربط بالذكاء الاصطناعي: حساب كسب المعلومات (26.7).

مثال (26.3-8): اعتماد تامّ المعطيات: $Y = X$. المطلوب: $H(Y \mid X)$. الحل: الخطوة 1: معرفة X تعيّن $Y \Rightarrow 0$. النتيجة: صفر. الربط بالذكاء الاصطناعي: ميزة تكشف الهدف تماماً.

مثال (26.3-9): $H(X \mid X)$ المعطيات: نكيّف على نفسه. المطلوب: القيمة. الحل: الخطوة 1: 0 دائماً. النتيجة: لا شكّ بعد المعرفة. الربط بالذكاء الاصطناعي: تحقّق من التنفيذ.

مثال (26.3-10): إنتروبيا bigram المعطيات: نموذج لغوي بالأزواج. المطلوب: الإنتروبيا الشرطية. الحل: الخطوة 1: $H(X_2 \mid X_1)$ = متوسط إنتروبيا التوزيع التالي. النتيجة: يقيس صعوبة التنبّؤ. الربط بالذكاء الاصطناعي: perplexity من الإنتروبيا (الفصل 28).

مثال (26.3-11): معدّل الإنتروبيا لماركوف المعطيات: سلسلة ماركوف. المطلوب: المعدّل. الحل: الخطوة 1: $H(X_1..X_n) = H(X_2 \mid X_1)$ للثابتة. النتيجة: معدّل معلومات المصدر. الربط بالذكاء الاصطناعي: تقييم نماذج التسلسل.

مثال (26.3-12): حدّ أعلى للمشتركة المعطيات: $H(X), H(Y)$. المطلوب: الحدّ. الحل: الخطوة 1: $H(X,Y) \leq H(X) + H(Y)$ (تساوي عند الاستقلال). النتيجة: subadditivity. الربط بالذكاء الاصطناعي: الترميز المشترك لا يكلّف أكثر من المنفصل.

مثال (26.3-13): استقلال شرطي المعطيات: $X \perp Y \mid Z$. المطلوب: الأثر. الحل: الخطوة 1: $H(X,Y \mid Z) = H(X \mid Z) + H(Y \mid Z)$. النتيجة: تبسيط كبير. الربط بالذكاء الاصطناعي: نماذج الرسوم الاحتمالية (من 16).

مثال (26.3-14): ضغط الأزواج المعطيات: ترميز (X,Y) معاً. المطلوب: الفائدة. الحل: الخطوة 1: الترميز المشترك أرخص من المنفصل عند الاعتماد. النتيجة: مبدأ الضغط. الربط بالذكاء الاصطناعي: تمثيلات مشتركة/مدمجة.

مثال (26.3-15): تلخيص المعطيات: كلّ ما سبق. المطلوب: العلاقة. الحل: الخطوة 1: قاعدة السلسلة تعمّم لأيّ عدد متغيّرات. النتيجة: أداة حسابية أساسية. الربط بالذكاء الاصطناعي: تحليل النماذج الاحتمالية.

أخطاء شائعة

- افتراض $H(X,Y) = H(X) + H(Y)$ بلا تحقّق من الاستقلال.
- نسيان أنّ الإنتروبيا الشرطية متوسط مرجّح.

- الخلط بين $H(Y \mid X)$ و $H(Y \mid X = x)$.
- استخدام هامش خاطئ عند حساب الشرطية.

$$I(X;Y) \;=\; H(X) - H(X \mid Y) \;=\; H(Y) - H(Y \mid X) \;=\; \sum_{x,y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \tag{3.26}$$

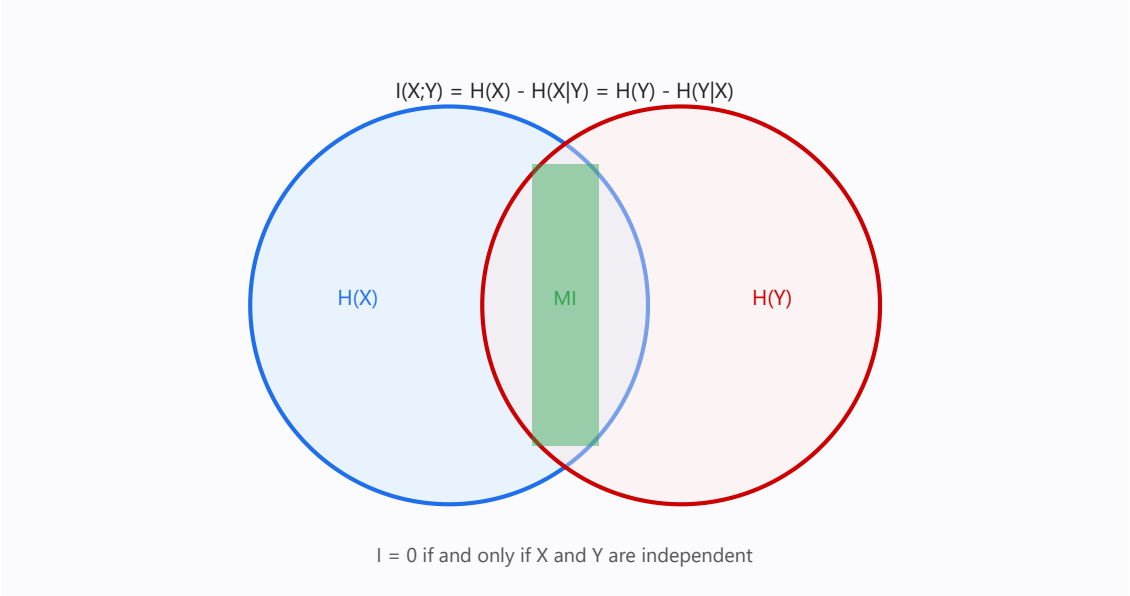
وهي غير سالبة، وتصفُر إذا وفقط إذا كان X, Y مستقلّين.

جدول الرموز

الرمز	المعنى
$I(X;Y)$	المعلومات المتبادلة
$\frac{p(x,y)}{p(x)p(y)}$	نسبة الاعتماد
D_{KL}	تباعد كولباك-لايبلر (الفصل 27)
تماثل	$I(X;Y) = I(Y;X)$

الرسم

<figure> الشكل<figcaption> 3.26: المعلومات المتبادلة هي التقاطع: ما يشتركان فيه من معلومات.</figcaption>



شكل ٣.٢٦: *
المعلومات المتبادلة كتقاطع

</figure>

البرهان (مخطّط)

الصيغة الأخيرة في (3.26) هي $D_{KL}(p_{XY} \| p_X p_Y) \;\geq\; 0$ (مبرهنة جيبس، الفصل 27)، والمساواة بصفر تكافئ $p_{XY} = p_X p_Y$ أي الاستقلال. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.26): الحساب بالفرق المعطيات: $H(X) = 2$، $H(X \mid Y) = 0.7$. المطلوب: I. الحل: الخطوة 1: $2 - 0.7 = 1.3$. النتيجة: 1.3 بت. الربط بالذكاء الاصطناعي: كم تخبرنا Y عن X؟

مثال (2-4.26): التماثل المعطيات: $I(X;Y) = I(Y;X)$. المطلوب: $I(Y;X)$. الحل: الخطوة 1: نفس القيمة. النتيجة: متماثلة دائماً. الربط بالذكاء الاصطناعي: «كم نعرف عن» علاقة ثنائية الاتجاه.

مثال (3-4.26): عدم السلبية المعطيات: أيّ متغيّرين. المطلوب: الحدّ. الحل: الخطوة 1: $I \geq 0$ دائماً (بجيبس). النتيجة: لا «معلومات سالبة». الربط بالذكاء الاصطناعي: تحقّق من صحة الحساب.

مثال (4-4.26): الاستقلال المعطيات: $X \perp Y$. المطلوب: I. الحل: الخطوة 1: $H(X \mid Y) = H(X) \Rightarrow I = 0$. النتيجة: صفر. الربط بالذكاء الاصطناعي: ميزة لا علاقة لها بالهدف.

مثال (5-4.26): $I(X;X)$ المعطيات: نفس المتغيّر. المطلوب: القيمة. الحل: الخطوة 1: $H(X) - 0 = H(X)$. النتيجة: الإنتروبيا نفسها. الربط بالذكاء الاصطناعي: الحدّ الأقصى للمعلومات الذاتية.

مثال (6-4.26): الصلة بـ KL المعطيات: نسبة الاعتماد. المطلوب: العلاقة. الحل: الخطوة 1: $I = D_{KL}(p_{XY} \| p_X p_Y)$. النتيجة: وصل بالفصل 27. الربط بالذكاء الاصطناعي: أساس حدود التباين.

مثال (7-4.26): تلازم الكلمات المعطيات: «نيويورك». المطلوب: الاستخدام. الحل: الخطوة 1: MI عالية $\Rightarrow$ تلازم حقيقي. النتيجة: استخراج العبارات. الربط بالذكاء الاصطناعي: معالجة اللغة الطبيعية.

مثال (8-4.26): اختيار الميزات المعطيات: 1000 ميزة وهدف. المطلوب: الطريقة. الحل: الخطوة 1: نحسب $I(X_j;Y)$ ونختار الأعلى. النتيجة: تصفية غير خطّية. الربط بالذكاء الاصطناعي: feature filter-based، selection.

مثال (9-4.26): أشجار القرار المعطيات: نبحث أفضل فصل. المطلوب: المعيار. الحل: الخطوة 1: نعظّم $I(\text{feature; target})$ = كسب المعلومات (7.26). النتيجة: المعيار الكلاسيكي. الربط بالذكاء الاصطناعي: ID3/C4.5.

مثال (10-4.26): التعلّم التمثيلي المعطيات: تمثيلان لعرضين مختلفين. المطلوب: الهدف. الحل: الخطوة 1: نعظّم MI بينهما (مثل InfoNCE/التباين.). النتيجة: تمثيلات متسقة عبر العروض. الربط بالذكاء الاصطناعي: contrastive learning.

مثال (11-4.26): عنق زجاجة المعلومات المعطيات: شبكة عميقة. المطلوب: الإطار. الحل: الخطوة 1: نعظّم $I(Z;Y)$ ونقلّل $I(Z;X)$. النتيجة: ضغط مفيد. الربط بالذكاء الاصطناعي: Information Bottleneck.

مثال (12-4.26): مثال رقمي المعطيات: جدول 2×2. المطلوب: I. الحل: الخطوة 1: نحسب $H(X)$، $H(X \mid Y)$، ثمّ الفرق. النتيجة: قيمة بالبتّات. الربط بالذكاء الاصطناعي: تحقّق يدوي قبل التنفيذ.

مثال (13-4.26): MI مقابل الارتباط المعطيات: علاقة غير خطّية. المطلوب: أيهما يكشفها؟ الحل: الخطوة 1: MI يكشف أيّ اعتماد؛ الارتباط الخطّي قد يفشل. النتيجة: MI أعمّ. الربط بالذكاء الاصطناعي: كشف اعتمادات معقّدة.

مثال (14-4.26): MI الشرطية المعطيات: نعرف Z. المطلوب: التعريف. الحل: الخطوة 1: $I(X;Y \mid Z) = H(X \mid Z) - H(X \mid Y,Z)$. النتيجة: معلومات متبادلة بعد التكييف. الربط بالذكاء الاصطناعي: اختيار ميزات واعٍ بالسياق.

مثال (15-4.26): مترابحة معالجة البيانات المعطيات: $X \to Y \to Z$. المطلوب: النتيجة. الحل: الخطوة 1: $I(X;Z) \leq I(X;Y)$ (المعالجة لا تزيد المعلومات). النتيجة: مبدأ أساسي. الربط بالذكاء الاصطناعي: حدود ما يمكن للطبقات استخراجه.

أخطاء شائعة

- توقّع أنّ MI مقياس «مسافة» (ليست كذلك).
- حساب MI بعينات قليلة فتظهر قيم متحيّزة إيجاباً.
- نسيان أنّ MI لا تصف اتجاه السببية.

- الخلط بين MI والارتباط الخطّي.

$$0 \le H(X) \le \log |\mathcal{X}|, \qquad H \text{ مقعّرة في } p, \qquad H(Y \mid X) \le H(Y) \tag{4.26}$$

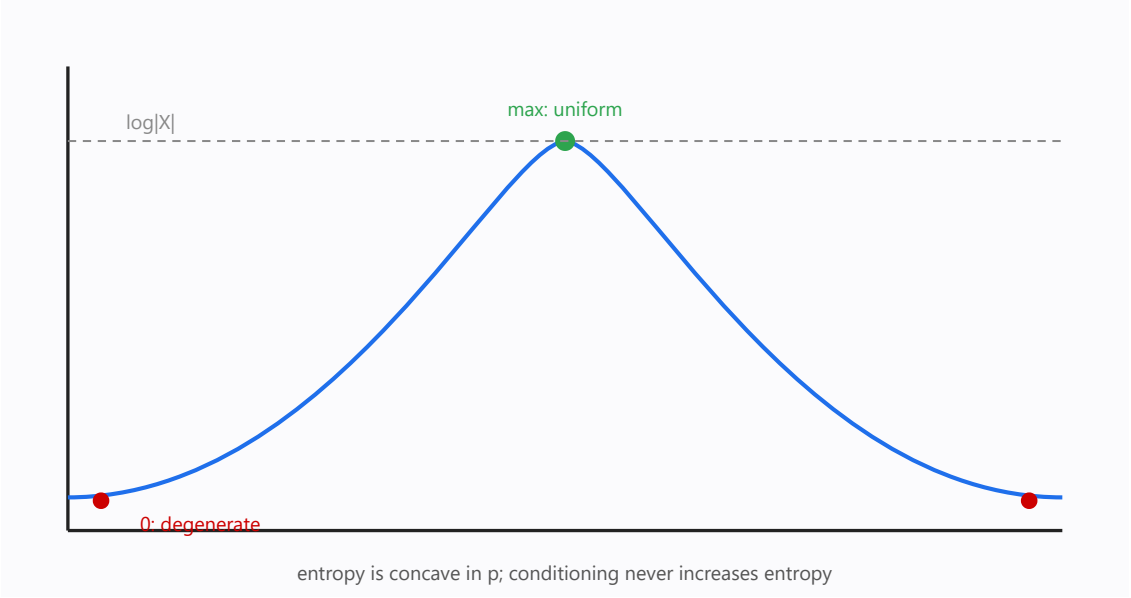
والمساواة في الحدّ الأعلى تحصل إذا وفقط إذا كان التوزيع منتظماً.

جدول الرموز

الرمز	المعنى
$\lvert\mathcal{X}\rvert$	حجم الدعم
مقعّرة	$H(\lambda p + (1-\lambda)q) \ge \lambda H(p) + (1-\lambda)H(q)$
تقليل بالتكييف	المعلومات تخفض الشكّ
جنسن	الأداة الأساسية (من 4.15)

الرسم

<figure> الشكل<figcaption> 4.26: الإنتروبيا مقعّرة في التوزيع؛ ذروتها عند المنتظم، وصفريّة عند



شكل ٤.٢٦: *
خصائص الإنتروبيا: التقعر والحد الأقصى

المتدهور.</figcaption> </figure>

البرهان (مخطّط)

الحدّ الأعلى: بمتراجحة جيبس $H = -\sum p \log p \le -\sum p \log q$ بـ q منتظم $= \log |\mathcal{X}|$. التقعّر من أنّ $-t \log t$ مقعّرة (مشتقّتها الثانية $-\frac{1}{t} < 0$). تقليل التكييف: $H(Y) - H(Y \mid X) = I(X;Y) \ge 0$. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.26): حدّ أعلى المعطيات: متغيّر بـ 8 قيم. المطلوب: أقصى H. الحل: الخطوة 1: $\log_2 8 = 3$. النتيجة: 3 بتّات. الربط بالذكاء الاصطناعي: أقصى شكّ لـ 8 فئات.

مثال (2-5.26): شرط المساواة المعطيات: $H = \log|\mathcal{X}|$. المطلوب: التوزيع. الحل: الخطوة 1: منتظم فقط. النتيجة: شرط إذا وفقط إذا. الربط بالذكاء الاصطناعي: تهيئة محايدة = منتظم.

مثال (3-5.26): التقعّر المعطيات: خلط توزيعين. المطلوب: النتيجة. الحل: الخطوة 1: إنتروبيا الخليط $\geq$ مرجّح الإنتروبيتين. النتيجة: الخلط يزيد الشكّ. الربط بالذكاء الاصطناعي: تنعيم التسميات يزيد الإنتروبيا.

مثال (4-5.26): إثبات بجنسن المعطيات: $-t\log t$ مقعّرة. المطلوب: الاستنتاج. الحل: الخطوة 1: بجنسن للتوقّع (من 4.15) $\Rightarrow$ التقعّر. النتيجة: برهان مباشر. الربط بالذكاء الاصطناعي: أداة متكرّرة في البراهين.

مثال (5-5.26): أقصى إنتروبيا بلا قيود المعطيات: دعم منتهٍ بلا قيود أخرى. المطلوب: التوزيع. الحل: الخطوة 1: المنتظم. النتيجة: مبدأ اللاأدريّة. الربط بالذكاء الاصطناعي: تهيئة softmax المتساوية.

مثال (6-5.26): إنتروبيا الخليط المعطيات: نخلط توزيعين متدهورين. المطلوب: الملاحظة. الحل: الخطوة 1: الخليط له إنتروبيا > 0 رغم مكوّنين بـ 0. النتيجة: عدم يقين من عدم المعرفة. الربط بالذكاء الاصطناعي: توزيعات مختلطة في النماذج.

مثال (7-5.26): تقليل التكييف المعطيات: أيّ ميزة. المطلوب: المتراجحة. الحل: الخطوة 1: $H(Y \mid X) \leq H(Y)$. النتيجة: معلومات لا تزيد الشكّ بالمتوسط. الربط بالذكاء الاصطناعي: كلّ سؤال يقلّل الشكّ.

مثال (8-5.26): التساوي في التكييف المعطيات: $H(Y \mid X) = H(Y)$. المطلوب: الاستنتاج. الحل: الخطوة 1: $I(X;Y) = 0 \Rightarrow$ استقلال. النتيجة: الميزة لا تفيد. الربط بالذكاء الاصطناعي: حذف ميزات غير مفيدة.

مثال (9-5.26): شبه الجمعيّة المعطيات: $H(X,Y)$. المطلوب: الحدّ. الحل: الخطوة 1: $H(X,Y) \leq H(X) + H(Y)$. النتيجة: subadditivity. الربط بالذكاء الاصطناعي: تمثيلات موزّعة.

مثال (10-5.26): متراجحة فانو تمهيداً المعطيات: نتنبّأ بـ X من Y. المطلوب: الحدّ. الحل: الخطوة 1: $P_e \geq \frac{H(X|Y)-1}{\log|\mathcal{X}|}$ (الفصل 31). النتيجة: شكّ $\Rightarrow$ خطأ حتمي. الربط بالذكاء الاصطناعي: حدود دنيا للخطأ.

مثال (11-5.26): النمطيّة (AEP) المعطيات: n عيّنة مستقلّة. المطلوب: الملاحظة. الحل: الخطوة 1: $-\frac{1}{n}\log p(X^n) \to H(X)$ بالاحتمال. النتيجة: أساس الضغط (الفصل 28). الربط بالذكاء الاصطناعي: احتمال الجمل في نماذج اللغة.

مثال (12-5.26): متراجحة جيبس تمهيداً المعطيات: توزيعان p, q. المطلوب: النتيجة. الحل: الخطوة 1: $-\sum p\log p \leq -\sum p\log q$ (التفاصيل في 27). النتيجة: الإنتروبيا المتقاطعة $\geq$ الإنتروبيا. الربط بالذكاء الاصطناعي: تبرير خسارة CE.

مثال (13-5.26): الإنتروبيا والضغط المعطيات: مصدر بإنتروبيا H. المطلوب: الحدّ. الحل: الخطوة 1: لا ضغط دون خسارة تحت H بت/رمز. النتيجة: حدّ شانون. الربط بالذكاء الاصطناعي: ضغط النماذج/التقطير.

مثال (14-5.26): لماذا الإنتروبيا الأعظمية؟ المعطيات: قيود جزئية. المطلوب: المبرّر. الحل: الخطوة 1: اختيار أيّ توزيع آخر يضيف افتراضات لا تبرّرها القيود. النتيجة: أقلّ التزام (8.26). الربط بالذكاء الاصطناعي: تبرير softmax.

مثال (15-5.26): مكافأة الإنتروبيا في التعلّم المعزّز المعطيات: نضيف $\beta H(\pi)$ للهدف. المطلوب: الأثر. الحل: الخطوة 1: يشجّع الاستكشاف ويمنع الانهيار المبكر. النتيجة: استكشاف مدعوم نظريّاً. الربط بالذكاء الاصطناعي: SAC و PPO بإنتروبيا.

أخطاء شائعة

- افتراض أنّ إنتروبيا الخليط تساوي مرجّح المكوّنات.
- نسيان أنّ الحدّ الأعلى يعتمد على حجم الدعم لا عدد العيّنات.
- الخلط بين تقعّر الإنتروبيا وتحدّبها في p.

- تجاهل أنّ التكييف يقلّل بالمتوسط لا لكلّ قيمة.

لمتغيّر مستمرّ بكثافة f:

$$h(X) = -\int_{\mathcal{X}} f(x)\log f(x)\,dx, \qquad h(\mathcal{N}(\mu,\sigma^2)) = \frac{1}{2}\log\!\left(2\pi e\,\sigma^2\right) \tag{5.26}$$

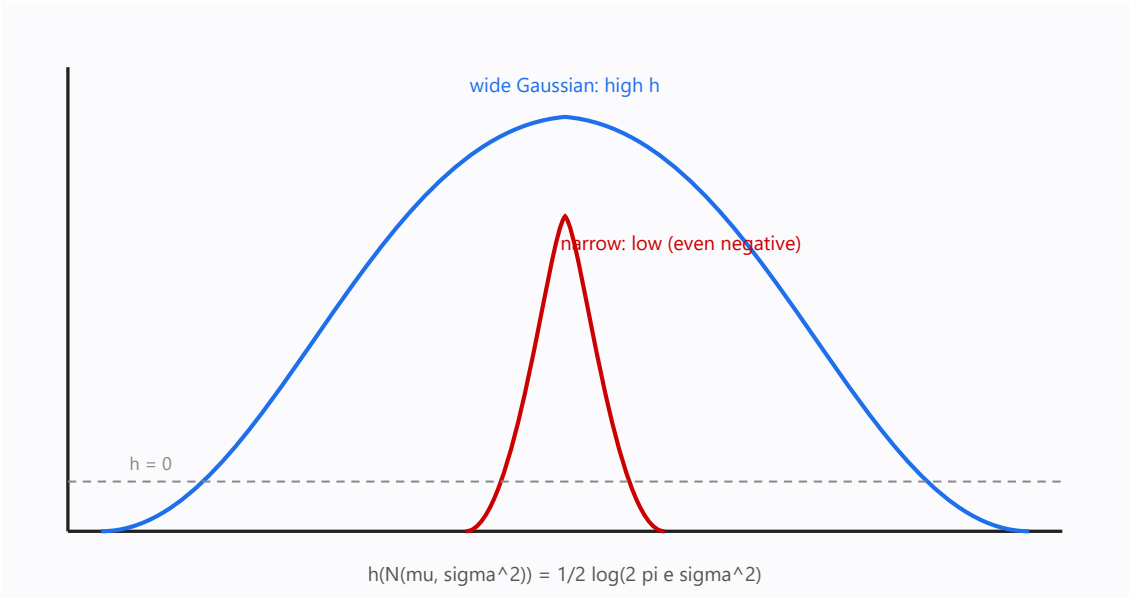
وهي **ليست** حدّاً لإنتروبيا منفصلة، وقد تكون سالبة.

جدول الرموز

الرمز	المعنى
$h(X)$	الإنتروبيا التفاضلية
f	الكثافة
$2\pi e$	ثابت الغاوسي
نات	الوحدة المعتادة هنا

الرسم

<figure> الشكل<figcaption> 5.26: للغاوسي تنمو الإنتروبيا مع التباين؛ وقد تكون سالبة لتباين ضيّق



شكل ٥.٢٦: *
الإنتروبيا التفاضلية للمتغيرات المستمرة

جدّاً.</figcaption> </figure>

البرهان (مخطّط)

للغاوسي: $h = -\mathbb{E}[\log f] = \frac{1}{2}\log(2\pi\sigma^2) + \frac{1}{2\sigma^2}\mathbb{E}[(X-\mu)^2] = \frac{1}{2}\log(2\pi\sigma^2) + \frac{1}{2} = \frac{1}{2}\log(2\pi e\sigma^2)$ باستخدام $\log e = 1$ بالنات. ■

خمسة عشر مثالاً محلولاً

مثال (26.6-1): تعريف المعطيات: كثافة f على $\mathbb{R}$. المطلوب: الصيغة. الحل: الخطوة 1: $h = -\int f \log f$. النتيجة: نظير الإنتروبيا للمستمرّ. الربط بالذكاء الاصطناعي: إنتروبيا التوزيعات المستمرّة في النماذج.

مثال (26.6-2): منتظم على فترة المعطيات: $U[0, a]$. المطلوب: h. الحل: الخطوة 1: $= -\int_0^a \frac{1}{a} \log \frac{1}{a} dx$ $\log a$. النتيجة: $\log a$ نات. الربط بالذكاء الاصطناعي: إنتروبيا تهيئة منتظمة.

مثال (26.6-3): غاوسي قياسي المعطيات: $\mathcal{N}(0, 1)$. المطلوب: h. الحل: الخطوة 1: $\approx \frac{1}{2}\ln(2\pi e)$ $= \frac{1}{2}(2.838) = 1.419$. النتيجة: ≈ 419.1 نات. الربط بالذكاء الاصطناعي: إنتروبيا أولية في VAE.

مثال (26.6-4): غاوسي بتباين 4 المعطيات: $\sigma^2 = 4$. المطلوب: h. الحل: الخطوة 1: $= \frac{1}{2}\ln(2\pi e \cdot 4)$ $= \frac{1}{2}\ln(8\pi e) \approx \frac{1}{2}(4.224) = 2.112$. النتيجة: ≈ 112.2 نات. الربط بالذكاء الاصطناعي: تباين أكبر $\Rightarrow$ شكّ أكبر.

مثال (26.6-5): أسّي المعطيات: $\text{Exp}(\lambda)$. المطلوب: h. الحل: الخطوة 1: $1 - \ln \lambda$. النتيجة: ينقص مع λ. الربط بالذكاء الاصطناعي: نمذجة أزمنة بإنتروبيا معلومة.

مثال (26.6-6): قيمة سالبة المعطيات: منتظم على $[0, 0.5]$. المطلوب: هل سالبة؟ الحل: الخطوة 1: $= \ln 0.5$ $0.693 < 0-$. النتيجة: نعم، سالبة. الربط بالذكاء الاصطناعي: لا تفسير «كتكافؤ بتّات» هنا.

مثال (26.6-7): أثر القياس المعطيات: $Y = aX$. المطلوب: $h(Y)$. الحل: الخطوة 1: $h(aX) = h(X) + \ln |a|$. النتيجة: غير ثابتة بالقياس. الربط بالذكاء الاصطناعي: تحذير عند مقارنة فضاءات مختلفة.

مثال (26.6-8): العلاقة بالمنفصلة المعطيات: نكمّم بخطوة Δ. المطلوب: التقريب. الحل: الخطوة 1: $\approx H(X^\Delta)$ $h(X) - \ln \Delta$. النتيجة: الإنتروبيا التفاضلية + تعويض. الربط بالذكاء الاصطناعي: ضغط الإشارات المستمرّة.

مثال (26.6-9): أقصى إنتروبيا بتباين ثابت المعطيات: نثبّت المتوسط والتباين. المطلوب: التوزيع. الحل: الخطوة 1: الغاوسي. النتيجة: نتيجة شهيرة. الربط بالذكاء الاصطناعي: تبرير الافتراض الغاوسي.

مثال (26.6-10): أقصى إنتروبيا على فترة المعطيات: دعم $[a, b]$ فقط. المطلوب: التوزيع. الحل: الخطوة 1: المنتظم. النتيجة: نظير الحالة المنفصلة. الربط بالذكاء الاصطناعي: تهيئات منتظمة.

مثال (26.6-11): قدرة الإنتروبيا المعطيات: $N(X) = \frac{1}{2\pi e} e^{2h(X)/d}$. المطلوب: المعنى. الحل: الخطوة 1: تباين «مكافئ» لغاوسي بنفس الإنتروبيا. النتيجة: مقياس قابل للمقارنة. الربط بالذكاء الاصطناعي: حدود الترميز.

مثال (26.6-12): KL للمستمرّ المعطيات: توزيعان بكثافتين. المطلوب: الصيغة. الحل: الخطوة 1: $= D_{KL}(p\|q)$ $\int p \ln \frac{p}{q}$ (الفصل 27). النتيجة: يبقى غير سالب. الربط بالذكاء الاصطناعي: تدريب النماذج التوليدية.

مثال (26.6-13): MI غاوسي المعطيات: متغيّران غاوسيان مشتركان بمعامل ارتباط ρ. المطلوب: I. الحل: الخطوة 1: $I = -\frac{1}{2}\ln(1 - \rho^2)$. النتيجة: يعتمد على الارتباط فقط. الربط بالذكاء الاصطناعي: تحليل التمثيلات الخطّية.

مثال (26.6-14): إنتروبيا فضاء كامن المعطيات: VAE بفضاء كامن غاوسي. المطلوب: الاستخدام. الحل: الخطوة 1: ننظّم بـ KL للغاوسي القياسي فنتحكّم بالإنتروبيا. النتيجة: تنظيم الفضاء الكامن. الربط بالذكاء الاصطناعي: VAE (الفصل 41).

مثال (26.6-15): صعوبة التقدير المعطيات: نريد تقدير h من عيّنات. المطلوب: التحذير. الحل: الخطوة 1: مقدّرات العيّنة متحيّزة؛ نستخدم مقدّرات تصحيحيّة (kNN/Kozachenko). النتيجة: حذر عملي. الربط بالذكاء الاصطناعي: تقدير MI في الشبكات (MINE).

أخطاء شائعة

- تفسير الإنتروبيا التفاضلية كبتّات ترميز.
- نسيان أنّها تتغيّر بإعادة القياس.
- توقّع عدم السلبية (قد تكون سالبة).

- الخلط بين $h(X)$ و $H(X)$ في الصيغ المختلطة.

كسب المعلومات من ميزة A نحو الهدف Y:

$$IG(Y;A) \;=\; H(Y) - H(Y \mid A) \;=\; I(Y;A), \qquad A^{\star} = \arg\max_{A} IG(Y;A) \tag{6.26}$$

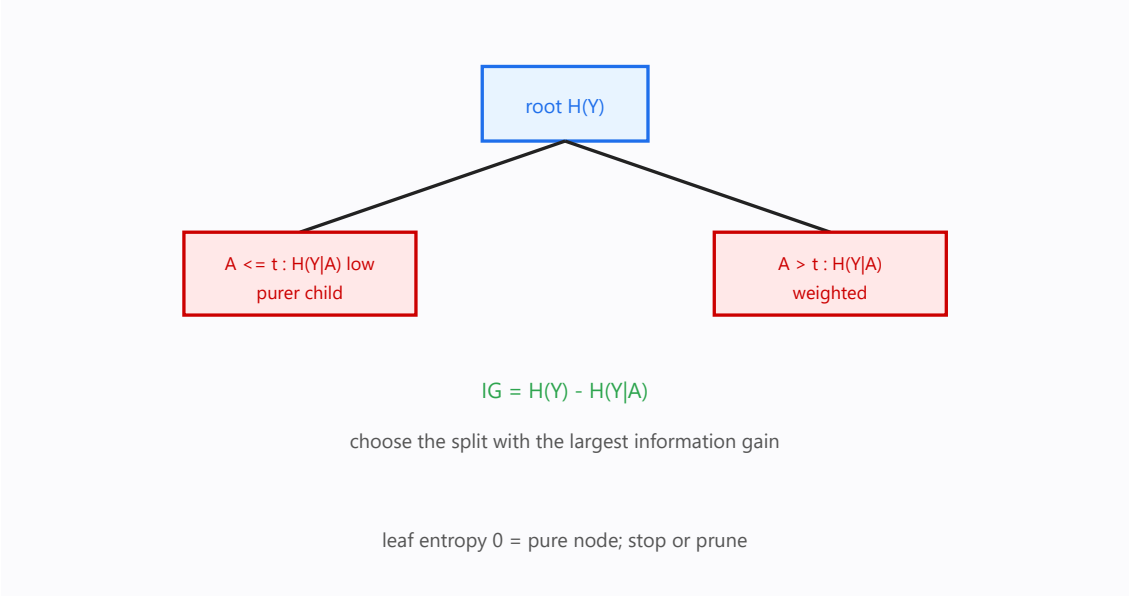
وهو معيار ID3 لاختيار أفضل فصل في الشجرة.

جدول الرموز

الرمز	المعنى
IG	كسب المعلومات
A	الميزة المرشّحة للفصل
$H(Y \mid A)$	الشكّ المتبقّي بعد الفصل
نقاء	إنتروبيا ورقة = 0 ⇒ نقية

الرسم

<figure> الشكل<figcaption> 6.26: كلّ فصل يقلّل إنتروبيا الهدف؛ نختار الفصل بأكبر كسب.</figcaption>



شكل ٦.٢٦: *
كسب المعلومات في أشجار القرار

</figure>

البرهان (مخطّط)

بقاعدة السلسلة (3.26): $H(Y) = H(Y \mid A) + I(Y;A)$، فتعظيم الكسب يكافئ تقليل الإنتروبيا الشرطية المرجّحة ⇒ أسرع تقليل للشكّ. ■

خمسة عشر مثالاً محلولاً

مثال (26.7-1): تعريف الكسب المعطيات: $H(Y) = 1$، $H(Y \mid A) = 0.3$. المطلوب: IG. الحل: الخطوة 1: $0.7 = 1 - 0.3$. النتيجة: 0.7 بت. الربط بالذكاء الاصطناعي: قوة الميزة التنبؤية.

مثال (26.7-2): حساب فصل المعطيات: فصل يقسم 100 إلى $(50 : 50)$ و $(10 : 40)$. المطلوب: الإنتروبيا المرجّحة. الحل: الخطوة 1: اليسار $H = 1$؛ اليمين $H = -0.8\log_2 0.8 - 0.2\log_2 0.2 \approx 0.722$. الخطوة 2: المرجّح $0.5(1) + 0.5(0.722) = 0.861$. النتيجة: 0.861 بت. الربط بالذكاء الاصطناعي: تقييم مرشّح فصل.

مثال (26.7-3): اختيار ID3 المعطيات: ميزتان بـ IG يساوي 0.4 و 0.6. المطلوب: أيهما؟ الحل: الخطوة 1: نختار الأعلى (0.6). النتيجة: أسرع تقليل للشكّ. الربط بالذكاء الاصطناعي: بناء الشجرة تكراريّاً.

مثال (26.7-4): نسبة الكسب (C4.5) المعطيات: ميزة بكثرة القيم. المطلوب: المشكلة. الحل: الخطوة 1: IG يميل للميزات كثيرة القيم $\Rightarrow$ نقسّم على $H(A)$. النتيجة: gain ratio. الربط بالذكاء الاصطناعي: تحسين C4.5 على ID3.

مثال (26.7-5): شائبة جيني المعطيات: بديل للإنتروبيا. المطلوب: الصيغة. الحل: الخطوة 1: $Gini = 1 - \sum_k p_k^2$. النتيجة: أرخص حسابيّاً ونتائج مشابهة. الربط بالذكاء الاصطناعي: CART/scikit-learn.

مثال (26.7-6): ميزة مستمرّة المعطيات: نبحث عتبة. المطلوب: الطريقة. الحل: الخطوة 1: نجرّب العتب عند نقاط مرشّحة ونختار أعلى IG. النتيجة: فصل ثنائي. الربط بالذكاء الاصطناعي: أشجار على ميزات رقمية.

مثال (26.7-7): الإفراط والتقليم المعطيات: شجرة حتى الأوراق النقية. المطلوب: الخطر. الحل: الخطوة 1: إفراط في التعلّم $\Rightarrow$ نقلّم أو نحدّ العمق. النتيجة: تعميم أفضل. الربط بالذكاء الاصطناعي: pruning و min_samples.

مثال (26.7-8): تصفية الميزات المعطيات: آلاف الميزات. المطلوب: الطريقة. الحل: الخطوة 1: نحسب IG لكلّ ميزة ونحتفظ بالأعلى. النتيجة: تقليل أبعاد موجّه. الربط بالذكاء الاصطناعي: preprocessing للنصوص.

مثال (26.7-9): MI = IG المعطيات: نفس الكمية. المطلوب: الملاحظة. الحل: الخطوة 1: $IG(Y; A) = I(Y; A)$ تماماً. النتيجة: توحيد المصطلحات. الربط بالذكاء الاصطناعي: ربط الأشجار بنظرية المعلومات.

مثال (26.7-10): تحيّز القيم الكثيرة المعطيات: ميزة «رقم الهوية». المطلوب: المشكلة. الحل: الخطوة 1: IG عالية جدّاً لكن بلا تعميم. النتيجة: سبب gain ratio. الربط بالذكاء الاصطناعي: تجنّب التسريب/المعرفات.

مثال (26.7-11): نقاء الورقة المعطيات: ورقة بكلّها من فئة واحدة. المطلوب: الإنتروبيا. الحل: الخطوة 1: $H = 0$. النتيجة: قرار حتمي. الربط بالذكاء الاصطناعي: شرط توقّف البناء.

مثال (26.7-12): أهمية الميزة في الغابة المعطيات: غابة عشوائية. المطلوب: القياس. الحل: الخطوة 1: نجمع تخفيض الإنتروبيا عبر كلّ الأشجار. النتيجة: ترتيب الميزات. الربط بالذكاء الاصطناعي: تفسير النماذج.

مثال (26.7-13): إنتروبيا شرطية للهدف المعطيات: نريد «كم بقي من شكّ؟». المطلوب: القراءة. الحل: الخطوة 1: $H(Y \mid A)$ بعد أفضل فصل. النتيجة: تقييم جودة الشجرة. الربط بالذكاء الاصطناعي: مراقبة البناء.

مثال (26.7-14): التقطيع (discretization) المعطيات: نقطّع ميزة مستمرّة. المطلوب: المعيار. الحل: الخطوة 1: نختار الحدود التي تعظّم IG. النتيجة: تحويل لميزة فئوية. الربط بالذكاء الاصطناعي: هندسة الميزات.

مثال (26.7-15): كلمات دالّة في التصنيف المعطيات: تصنيف نصوص. المطلوب: الاستخدام. الحل: الخطوة 1: أعلى IG $\Rightarrow$ الكلمات الأكثر تمييزاً. النتيجة: تفسير وتقليل أبعاد. الربط بالذكاء الاصطناعي: تحليل المشاعر/التصنيف.

أخطاء شائعة

- اختيار الميزة بكثرة القيم بلا تصحيح.
- الاستمرار حتى إنتروبيا صفر $\Rightarrow$ إفراط.

- الخلط بين IG و Gini كمعيارين متكافئين تماماً (متشابهان لا متطابقان).
- نسيان ترجيح إنتروبيا الفروع بأحجامها.

نعظّم الإنتروبيا تحت قيود لحظية (مثل $\mathbb{E}[f_i(X)] = \alpha_i$):

$$\max_{p} \; H(p) \quad \text{s.t.} \quad \mathbb{E}[f_i] = \alpha_i, \; \sum p = 1 \implies p(x) \propto \exp\Big(\sum_i \lambda_i f_i(x)\Big) \tag{7.26}$$

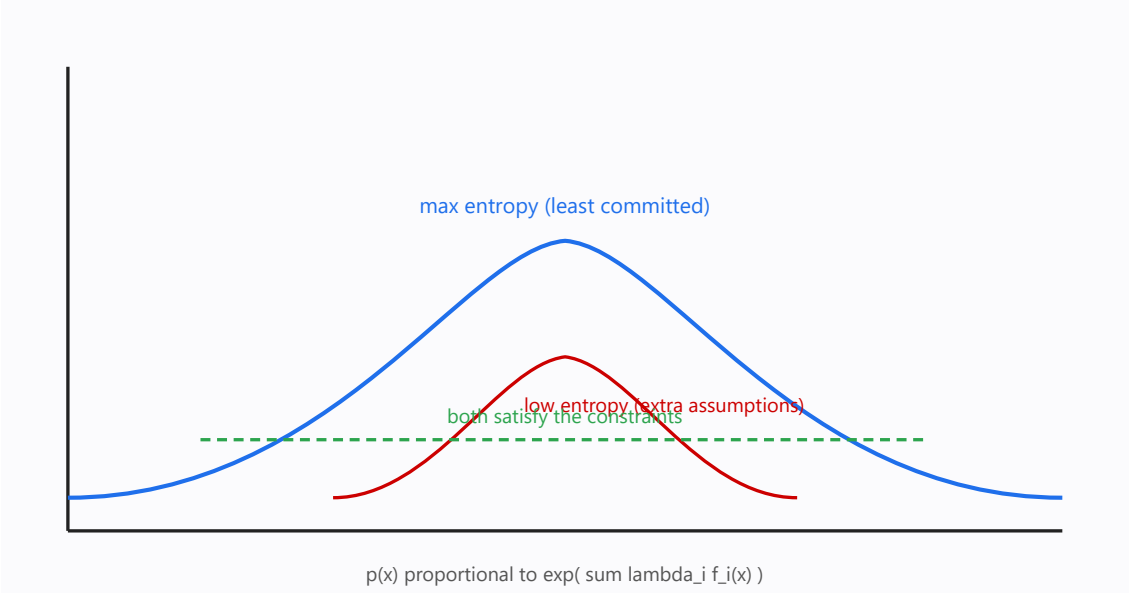
ومنها تظهر softmax واللوجستي والتوزيعات الأسّية.

جدول الرموز

الرمز	المعنى
f_i	دالّة الميزة/القيد
λ_i	مضاعف لاغرانج (من 21)
أسّية	عائلة التوزيعات الناتجة
softmax	الحالة الخاصة للتصنيف

الرسم

<figure> الشكل<figcaption> 7.26: بين كلّ التوزيعات المتوافقة مع القيود، نختار أعلى إنتروبيا = أقلّ



شكل ٧.٢٦: *
مبدأ الإنتروبيا الأعظمية والتوزيعات الأسية

التزام.<figcaption/> </figure>

البرهان (مخطّط)

نبني اللاغرانجي (من 2.21) $L = H + \sum \lambda_i(\mathbb{E}[f_i] - \alpha_i) + \nu(\sum p - 1)$، بالتصفير نحو $p(x)$: $-\log p - 1 + \dots$
$\Rightarrow p \propto e^{\sum \lambda_i f_i} \Rightarrow \sum \lambda_i f_i + \nu = 0$. (7.26) ■

خمسة عشر مثالاً محلولاً

مثال (26.8-1): بيان المبدأ المعطيات: قيود جزئية عن التوزيع. المطلوب: القاعدة. الحل: الخطوة 1: اختر أعلى إنتروبيا بين المتوافقة. النتيجة: أقلّ افتراض إضافي. الربط بالذكاء الاصطناعي: تبرير النماذج الاحتمالية.

مثال (26.8-2): قيد المتوسط ⇒ أسّي المعطيات: $\mathbb{E}[X] = \mu$ على $x \geq 0$. المطلوب: الشكل. الحل: الخطوة 1: $p \propto e^{\lambda x}$ ⇒ أسّي (بعد التطبيع). النتيجة: التوزيع الأسّي. الربط بالذكاء الاصطناعي: نمذجة أزمنة الانتظار.

مثال (26.8-3): بلا قيود ⇒ منتظم المعطيات: دعم منتهٍ فقط. المطلوب: التوزيع. الحل: الخطوة 1: تعظيم الإنتروبيا يعطي المنتظم. النتيجة: مبدأ اللاأدريّة. الربط بالذكاء الاصطناعي: تهيئة محايدة.

مثال (26.8-4): متوسط وتباين ⇒ غاوسي المعطيات: نثبّت المتوسط والتباين على $\mathbb{R}$. المطلوب: التوزيع. الحل: الخطوة 1: $p \propto e^{\lambda_1 x + \lambda_2 x^2}$ ⇒ غاوسي. النتيجة: تبرير الافتراض الغاوسي. الربط بالذكاء الاصطناعي: ضجيج غاوسي في النماذج.

مثال (26.8-5): مصنّف الإنتروبيا الأعظمية المعطيات: نثبّت تواتر الميزات المتوقّعة. المطلوب: الشكل. الحل: الخطوة 1: $p(y \mid x) \propto e^{\sum w_i f_i(x,y)}$ ⇒ لوجستي/softmax. النتيجة: الانحدار اللوجستي = MaxEnt. الربط بالذكاء الاصطناعي: تبرير softmax في الشبكات.

مثال (26.8-6): softmax من MaxEnt المعطيات: درجات z_k لكلّ فئة. المطلوب: التوزيع. الحل: الخطوة 1: $p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$. النتيجة: الخيار الأقلّ التزاماً بدرجات معلومة. الربط بالذكاء الاصطناعي: طبقة المخرجات في كلّ مصنّف.

مثال (26.8-7): العائلة الأسّية المعطيات: الصيغة الناتجة. المطلوب: الاسم. الحل: الخطوة 1: عائلة أسّية (exponential family) بميزات f_i. النتيجة: إطار يوحّد توزيعات كثيرة. الربط بالذكاء الاصطناعي: نماذج خطّية معمّمة (GLM).

مثال (26.8-8): توزيع بولتزمان المعطيات: فيزياء إحصائية. المطلوب: الشكل. الحل: الخطوة 1: $p \propto e^{-E/kT}$ من تعظيم الإنتروبيا بطاقة ثابتة. النتيجة: توزيع Gibbs. الربط بالذكاء الاصطناعي: نماذج الطاقة (EBM).

مثال (26.8-9): مضاعفات لاغرانج المعطيات: قائمة القيود. المطلوب: الطريقة. الحل: الخطوة 1: نطبّق إطار لاغرانج من الفصل 21. النتيجة: توحيد الأدوات. الربط بالذكاء الاصطناعي: نظرية + خوارزمية.

مثال (26.8-10): MaxEnt في اللغة المعطيات: مصنّف نصوص بقيود n-gram. المطلوب: الاستخدام. الحل: الخطوة 1: تدريب MaxEnt بقيود الميزات ⇒ مصنّف قويّ. النتيجة: تاريخياً مهمّ في البرمجة اللغوية. الربط بالذكاء الاصطناعي: MaxEnt classfiier.

مثال (26.8-11): توزيع الأنواع المعطيات: قيود بيئية. المطلوب: النموذج. الحل: الخطوة 1: MaxEnt يتنبّأ بتوزيع الانتشار. النتيجة: تطبيق بيئي. الربط بالذكاء الاصطناعي: نمذجة انتشار/توزيع.

مثال (26.8-12): التعلّم المعزّز بالإنتروبيا المعطيات: نعظّم العائد + إنتروبيا السياسة. المطلوب: الأثر. الحل: الخطوة 1: سياسة أسّية softmax) على Q) ⇒ استكشاف طبيعي. النتيجة: سياسات/SAC ناعمة. الربط بالذكاء الاصطناعي: RL MaxEnt (الفصل 44).

مثال (26.8-13): الثنائية المعطيات: تعظيم الإنتروبيا. المطلوب: الصيغة الثنائية. الحل: الخطوة 1: يكافئ تقليل لوغاريتم دالّة التقسيم (log-partition). النتيجة: صلة بالثنائية (الفصل 21). الربط بالذكاء الاصطناعي: تدريب نماذج أسّية.

مثال (26.8-14): MaxEnt و MLE المعطيات: عائلة أسّية. المطلوب: العلاقة. الحل: الخطوة 1: MLE داخل العائلة = حلّ MaxEnt بالقيود اللحظية. النتيجة: تطابق النتيجتين (من 18). الربط بالذكاء الاصطناعي: توحيد التقدير والتعظيم.

مثال (15-8.26): لماذا «أقلّ التزام»؟ المعطيات: توزيعان متوافقان مع القيود. المطلوب: المبرّر. الحل: الخطوة 1: الأقلّ إنتروبيا يضمّن افتراضات إضافية بلا دليل. النتيجة: MaxEnt هو الخيار المنهجي. الربط بالذكاء الاصطناعي: تبرير الانحيازات الضعيفة.

أخطاء شائعة

- نسيان قيد التطبيع في اللاغرانجي.
- الخلط بين تعظيم الإنتروبيا وتقليل الإنتروبيا المتقاطعة.
- افتراض أنّ MaxEnt يعطي دائماً توزيعاً بسيطاً.
- تجاهل أنّ القيود غير المتسقة تجعل المسألة غير ممكنة.

ملخّص النظريات

النظرية	المفهوم	الأهمّية
2.26 شانون	$H = -\sum p \log p$	مقياس الشكّ
3.26 المشتركة/الشرطية	$H(X,Y) = H(X) + H(Y \mid X)$	ترميز متسلسل
MI 4.26	$I = H(X) - H(X \mid Y)$	اختيار ميزات/تمثيلات
5.26 الخصائص	$H \le \log \lvert\mathcal{X}\rvert$، مقعّرة	تبرير CE و softmax
6.26 التفاضلية	$h = -\int f \log f$	المتغيّرات المستمرّة
7.26 كسب المعلومات	$IG = H(Y) - H(Y \mid A)$	أشجار القرار
MaxEnt 8.26	$p \propto e^{\sum \lambda_i f_i}$	softmax والأسّية

عشرون تمريناً (مع إجابات مختصرة)

١. إنتروبيا قطعة عادلة؟ (1 بت)

٢. إنتروبيا نرد عادل؟ ($\log_2 6 \approx 2.585$)

٣. إنتروبيا حدث مؤكّد؟ (0)

٤. قاعدة السلسلة؟ ($H(X,Y) = H(X) + H(Y \mid X)$)

٥. عند الاستقلال $H(X,Y)$؟ ($H(X) + H(Y)$)

٦. هل $H(Y \mid X) \le H(Y)$؟ (نعم)

٧. تعريف MI؟ ($H(X) - H(X \mid Y)$)

٨. متى $I = 0$؟ (عند الاستقلال)

٩. $I(X;X)$؟ ($H(X)$)

١٠. الحدّ الأعلى للإنتروبيا؟ ($\log \lvert\mathcal{X}\rvert$، بشرط المنتظم)

١١. هل الإنتروبيا مقعّرة في p؟ (نعم)

١٢. إنتروبيا غاوسي؟ ($\frac{1}{2}\log(2\pi e\sigma^2)$)

١٣. هل الإنتروبيا التفاضلية قد تكون سالبة؟ (نعم)

١٤. أقصى إنتروبيا بتباين ثابت؟ (الغاوسي)

١٥. كسب المعلومات؟ $(H(Y) - H(Y \mid A))$

١٦. لماذا gain ratio؟ (لتصحيح تحيّز كثرة القيم)

١٧. شائبة جيني؟ $(1 - \sum p_k^2)$

١٨. نتيجة MaxEnt بمتوسط ثابت؟ (توزيع أسّي)

١٩. نتيجة MaxEnt بمتوسط وتباين؟ (غاوسي)

٢٠. لماذا MaxEnt = softmax؟ (أقلّ التزام بدرجات معلومة)

فهرس الرموز

الرمز	المعنى
H	إنتروبيا (منفصلة)
h	إنتروبيا تفاضلية
$H(\cdot \mid \cdot)$	إنتروبيا شرطية
$I(X;Y)$	معلومات متبادلة
IG	كسب المعلومات

مراجع

- Shannon — «A Mathematical Theory of Communication».
- Thomas & Cover — *Elements of Information Theory*.
- MacKay — *Information Theory, Inference, and Learning Algorithms*.
- Jaynes — «Information Theory and Statistical Mechanics» (MaxEnt).
- Quinlan — «Induction of Decision Trees» (ID3) و C4.5.

خاتمة: الفصل 27 يواصل بـ **إنتروبيا التقاطع وتباعد KL وتباعدات ف-ديفرجنس**، حيث تتحوّل هذه المقاييس إلى دوالّ خسارة قابلة للتقليل.

إنتروبيا التقاطع، تباعد KL، وتباعدات ف-ديفرجنس

«خسارة الإنتروبيا المتقاطعة ليست اختياراً اعتباطيّاً؛ إنها أقصر وصف ممكن للفجوة بين ما نؤمن به وما هو صحيح.»

في الفصل السادس والعشرين بنينا الإنتروبيا. هذا الفصل يحوّلها إلى **أدوات قابلة للتقليل**: إنتروبيا التقاطع، تباعد كولباك-لايبلر، ثمّ التعميم في **تباعدات ف-ديفرجنس**. هذه المقاييس هي لغة تدريب النماذج الحديثة: الإنتروبيا المتقاطعة في التصنيف، KL في VAE و RL، تباعدات ف في GAN، وحدود دالّة قابلة للتعلّم في التعلّم التمثيلي.
سبع نظريات:

- **2.27 إنتروبيا التقاطع** — $H(p,q) = H(p) + D_{KL}(p\|q)$.
- **3.27 تباعد KL** — المقياس غير المتماثل للمسافة.
- **4.27 خصائص KL** — جيبس، السلسلة، معالجة البيانات.
- **5.27 تباعدات ف-ديفرجنس** — عائلة واحدة تضمّ KL و TV و Hellinger.
- **6.27 الحدود التباينية** — دالّة قابلة للتعلّم لتقدير KL في بعد عالٍ.
- **7.27 إنتروبيا التقاطع كخسارة** — softmax والتقطير.
- **8.27 مقارنة التباعدات** — JS و TV و Hellinger و Wasserstein.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

نكتب p للتوزيع «الحقيقي» (بيانات أو تسمية) و q لتوزيع النموذج.

الرمز	المعنى
$H(p,q)$	إنتروبيا التقاطع
$D_{KL}(p\|q)$	تباعد كولباك-لايبلر
D_f	تباعد ف-ديفرجنس
$m = \frac{p+q}{2}$	الخليط (لـ JS)
T, e^T	دالّة اختبار ودالّتها الأسّية

$$H(p,q) \;=\; -\sum_{x} p(x)\,\log q(x) \;=\; H(p) \;+\; D_{KL}(p\,\|\,q) \tag{1.27}$$

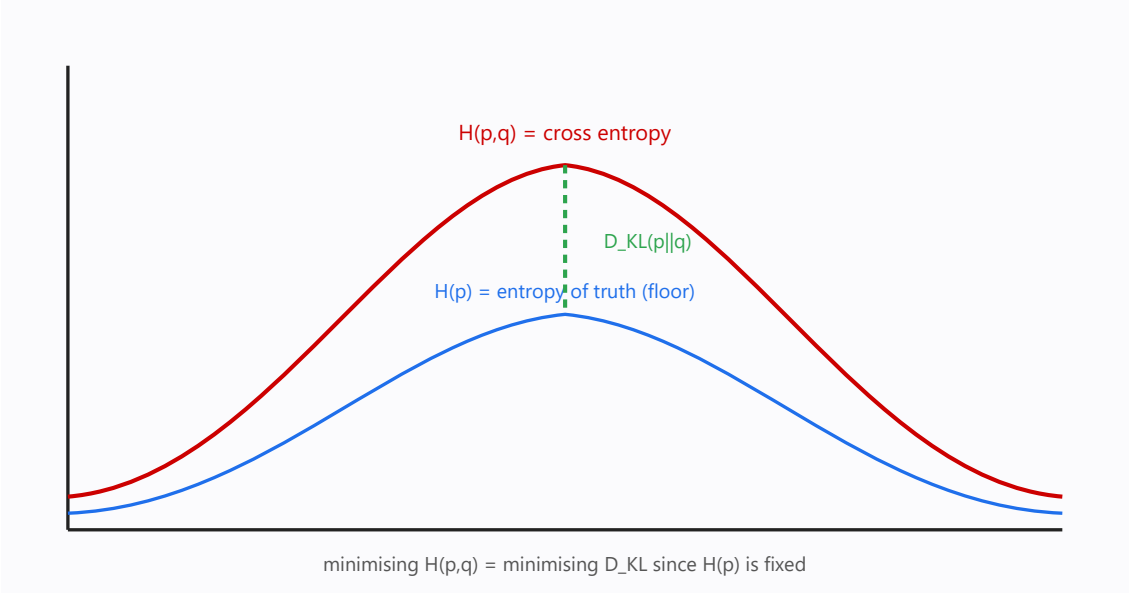
وهي «متوسّط مفاجأة» البيانات p عند قياسها بمنظور النموذج q.

جدول الرموز

الرمز	المعنى
p	التوزيع الحقيقي (هدف/حقيقي)
q	توزيع النموذج
$H(p)$	إنتروبيا الحقيقة (لا تتحكّم بها)
D_{KL}	الجزء القابل للتقليل

الرسم

<figure> الشكل<figcaption> 1.27: الإنتروبيا المتقاطعة = إنتروبيا ثابتة + KL، فالتقليل يتعلّق بـ KL



شكل ١.٢٧: *
إنتروبيا التقاطع: إنتروبيا الحقيقة زائد تباعد KL

وحدها.<figcaption/> </figure>

البرهان (مخطّط)

بفكّك $\log \frac{1}{q(x)} = \log \frac{1}{p(x)} + \log \frac{p(x)}{q(x)}$ وأخذ التوقّع تحت p، نحصل على $H(p) + D_{KL}(p\|q)$ مباشرة. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.27): تطابق تامّ المعطيات: $p = (0.5, 0.5)$، $q = (0.5, 0.5)$. المطلوب: $H(p, q)$. الحل: الخطوة 1: $D_{KL} = 0 \Rightarrow H = 1$. النتيجة: 1 بت (أدنى قيمة ممكنة). الربط بالذكاء الاصطناعي: نموذج مثالي على تسمية متساوية.

مثال (2-2.27): نموذج خاطئ المعطيات: $p = (1, 0)$ (واحد ساخن)، $q = (0.5, 0.5)$. المطلوب: $H(p, q)$. الحل: الخطوة 1: $H(p) = 0$، $H(p, q) = -\log 0.5 = 1$. الخطوة 2: $D_{KL} = 1$. النتيجة: 1 بت. الربط بالذكاء الاصطناعي: خسارة نموذج غير واثق على هدف مؤكّد.

مثال (3-2.27): أضعف احتمال المعطيات: $p = (1, 0)$، $q = (0.9, 0.1)$. المطلوب: $H(p, q)$. الحل: الخطوة 1: $-\log_2 0.9 \approx 0.152$. النتيجة: ≈ 0.152 بت. الربط بالذكاء الاصطناعي: ثقة عالية وخسارة منخفضة.

مثال (2.27-4): الحدّ الأدنى المعطيات: p ثابت. المطلوب: أدنى $H(p,q)$. الحل: الخطوة 1: يتحقّق عند $q = p$ (بجيبس في 4.27). النتيجة: $H(p)$. الربط بالذكاء الاصطناعي: الهدف الأمثل للتدريب.

مثال (2.27-5): السجلّ السلبي المعطيات: تسمية واحدة y (واحد ساخن). المطلوب: الخسارة. الحل: الخطوة 1: $-\log q_y$ (negative log-likelihood). النتيجة: NLL. الربط بالذكاء الاصطناعي: خسارة التصنيف في المكتبات.

مثال (2.27-6): الوحدات المعطيات: نستخدم ln. المطلوب: النتيجة. الحل: الخطوة 1: بالنات؛ والتحويل ثابت معروف (من 2.26). النتيجة: نات بدل بت. الربط بالذكاء الاصطناعي: المكتبات تستعمل النات.

مثال (2.27-7): تنعيم التسمية المعطيات: $y = (0.95, 0.05)$ بدل $(1, 0)$. المطلوب: الخسارة. الحل: الخطوة 1: $-(0.95 \ln q_1 + 0.05 \ln q_2)$. الخطوة 2: يمنع الثقة المفرطة. النتيجة: تعميم أفضل أحياناً. الربط بالذكاء الاصطناعي: label smoothing.

مثال (2.27-8): الحيرة (perplexity) المعطيات: $H = 3.32$ بت. المطلوب: perplexity. الحل: الخطوة 1: $2^{3.32} \approx 10$. النتيجة: وكأنّ 10 خيارات متساوية. الربط بالذكاء الاصطناعي: تقييم نماذج اللغة.

مثال (2.27-9): نموذج لغوي المعطيات: كلّ كلمة بتكرار p. المطلوب: متوسط الخسارة. الحل: الخطوة 1: $-\sum p_w \ln q_w$. النتيجة: خسارة الانتروبيا المتقاطعة. الربط بالذكاء الاصطناعي: تدريب نماذج اللغة.

مثال (2.27-10): عدم التماثل المعطيات: $H(p,q) \neq H(q,p)$ عموماً. المطلوب: هل مقيسة؟ الحل: الخطوة 1: لا، لأنّ التوقّع تحت p. النتيجة: ليس مقياساً. الربط بالذكاء الاصطناعي: ترتيب الأدوار مهمّ.

مثال (2.27-11): مشكلة $q = 0$ المعطيات: $q_y = 0$ للتسمية الصحيحة. المطلوب: الخسارة. الحل: الخطوة 1: لا نهائيّة. الخطوة 2: نضيف قبعة (clipping) أو نستخدم logsoftmax مستقرّاً. النتيجة: احتياطات عدديّة. الربط بالذكاء الاصطناعي: ثبات softmax الناتي.

مثال (2.27-12): التصنيف الثنائي المعطيات: $\hat{y} = \sigma(z)$. المطلوب: الخسارة. الحل: الخطوة 1: $-(y \ln \hat{y} + (1-y) \ln(1-\hat{y}))$. النتيجة: log loss. الربط بالذكاء الاصطناعي: المصنّف اللوجستي.

مثال (2.27-13): تدرّج CE + softmax المعطيات: تدرّج نحو z. المطلوب: الصيغة. الحل: الخطوة 1: $\hat{y} - y$ (من الفصل 9، مفاجأة لطيفة). الخطوة 2: لا عوامل انحناء كثيرة. النتيجة: تدرّج بسيط ومستقرّ. الربط بالذكاء الاصطناعي: سبب شيوع الزوج softmax+CE.

مثال (2.27-14): التقييم المعطيات: نموذج بدقّة 90٪. المطلوب: هل يكفي؟ الحل: الخطوة 1: الدقّة لا تكشف الثقة؛ CE تكشف. الخطوة 2: نموذج واثق خاطئ عقوبة قويّة. النتيجة: CE معيار أدقّ. الربط بالذكاء الاصطناعي: اختيار مقاييس التقييم.

مثال (2.27-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: العلاقة. الحل: الخطوة 1: تقليل CE = تقليل KL = مطابقة q لـ p. النتيجة: الهدف الموحّد للتدريب. الربط بالذكاء الاصطناعي: مبدأ التدريب الاحتمالي.

أخطاء شائعة

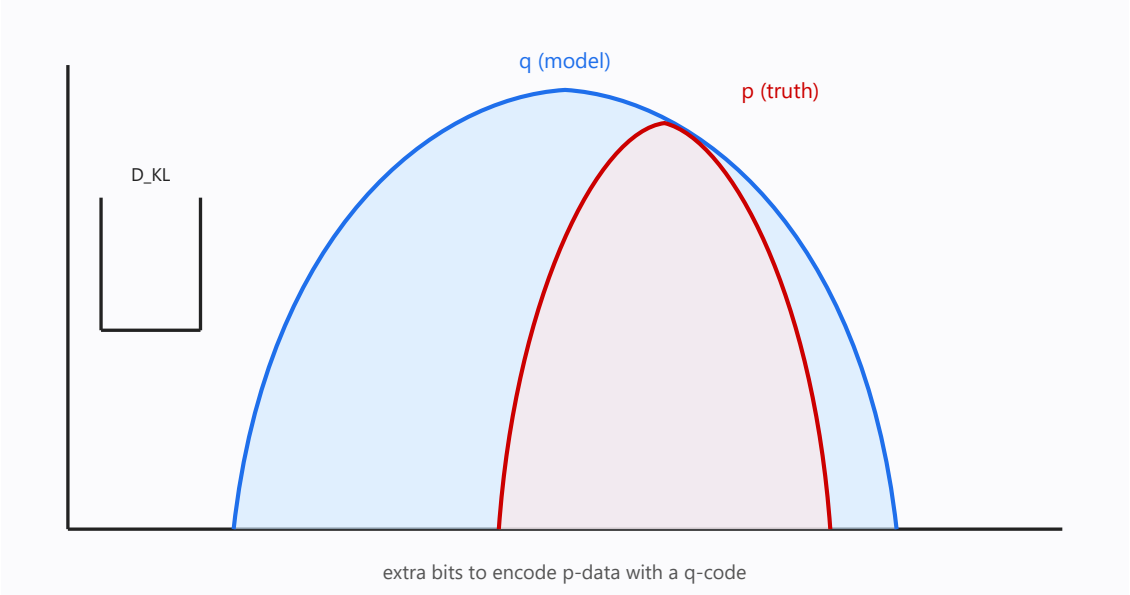
- الظن أنّ تقليل CE يتطلّب تقليل $H(p)$ (ثابتة).
- نسيان حصر $q = 0$ فتنفجر الخسارة.
- الخلط بين CE و KL (الأول فيها حدّ ثابت).
- استخدام MSE بدل CE في التصنيف فيبطأ التعلّم.

$$D_{KL}(p \,\|\, q) = \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)} = \mathbb{E}_p\left[\log \frac{p}{q}\right] \tag{2.27}$$

الرمز	المعنى
$\|\|$	اتجاه التباعد (أولاً p ثمّ q)
p	المرجع (منه نأخذ التوقّع)
q	التقريب
صفر	يكفيه $p = q$ على دعم p

الرسم

<figure> الشكل<figcaption> 2.27: $D_{KL}(p\|q)$ تكافئ عدد بتّات إضافية عند ترميز بيانات p بمخطّط



شكل ٢٠٢٧: *
تباعد KL: غير متماثل وبعدين

</figure> .</figcaption>q

البرهان (مخطّط)

طول الترميز بمنظور p هو $-\log p$؛ لو استخدمنا q يصير $-\log q$؛ الفارق المتوقّع $\mathbb{E}_p[\log \frac{p}{q}]$ هو «الفاقد» $\Rightarrow$ (2.27). ■

خمسة عشر مثالاً محلولاً

مثال (1-3.27): حساب مباشر المعطيات: $p = (0.6, 0.4)$، $q = (0.5, 0.5)$. المطلوب: $D_{KL}(p\|q)$. الحل: الخطوة 1: $0.6\log_2 \frac{0.6}{0.5} + 0.4\log_2 \frac{0.4}{0.5}$. الخطوة 2: $0.6(0.263) + 0.4(-0.322) = 0.158 - 0.129 = 0.029$. النتيجة: ≈ 0.029 بت. الربط بالذكاء الاصطناعي: كم نكلف بسبب نموذج خاطئ.

مثال (2-3.27): الاتجاه المعاكس المعطيات: $D_{KL}(q\|p)$ لنفس المثال. المطلوب: القيمة. الحل: الخطوة 1: $0.5\log_2 \frac{0.5}{0.6} + 0.5\log_2 \frac{0.5}{0.4} = 0.5(-0.263) + 0.5(0.322) = 0.0295$. النتيجة: ≈ 0.030 بت (مختلف قليلاً). الربط بالذكاء الاصطناعي: تذكير بعدم التماثل.

مثال (3-3.27): مساواة المعطيات: $p = q$. المطلوب: D_{KL}. الحل: الخطوة 1: $\log 1 = 0$. النتيجة: صفر. الربط بالذكاء الاصطناعي: الحالة المثلى.

مثال (4-3.27): دعم مختلف المعطيات: $p(x) > 0$ لكن $q(x) = 0$. المطلوب: D_{KL}. الحل: الخطوة 1: اللوغاريتم لا نهائي. الخطوة 2: لازم دعم p داخل دعم q (absolute continuity). النتيجة: لا نهائي. الربط بالذكاء الاصطناعي: تجنّب أصفار في softmax.

مثال (3.27-5): غاوسيان المعطيات: $p = \mathcal{N}(\mu_1, \sigma_1^2)$، $q = \mathcal{N}(\mu_2, \sigma_2^2)$. المطلوب: الصيغة المغلقة. الحل: الخطوة 1: $\log \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}$. النتيجة: صيغة معلومة. الربط بالذكاء الاصطناعي: KL للغاوسي في VAE.

مثال (3.27-6): برنولي المعطيات: p باحتمال p_0 و q باحتمال q_0. المطلوب: D_{KL}. الحل: الخطوة 1: $p_0 \log \frac{p_0}{q_0} + (1-p_0) \log \frac{1-p_0}{1-q_0}$. النتيجة: صيغة قياسية. الربط بالذكاء الاصطناعي: مقارنة مصنّفين.

مثال (3.27-7): KL وMI المعطيات: p_{XY} مقابل $p_X p_Y$. المطلوب: العلاقة. الحل: الخطوة 1: $I(X;Y) = D_{KL}(p_{XY} \| p_X p_Y)$. النتيجة: MI كحالة خاصّة. الربط بالذكاء الاصطناعي: وصل بالفصل 26.

مثال (3.27-8): KL الأمامي مقابل العكسي المعطيات: q أحاديّ القمّة و p متعدّد. المطلوب: السلوك. الحل: الخطوة 1: الأمامي $D_{KL}(p\|q)$ «يسعى للقمم» (mode-seeking). الخطوة 2: العكسي $D_{KL}(q\|p)$ «يغطّي الكتلة» (mass-covering). النتيجة: فرق جوهري عمليّاً. الربط بالذكاء الاصطناعي: اختيار الاتجاه في VAE و GAN.

مثال (3.27-9): KL في VAE المعطيات: خلفيّة $\mathcal{N}(0, I)$. المطلوب: الحدّ. الحل: الخطوة 1: $\frac{1}{2}\sum(\sigma_j^2 + \mu_j^2 - 1 - \ln \sigma_j^2)$. النتيجة: حدّ KL للغاوسي. الربط بالذكاء الاصطناعي: تدريب VAE.

مثال (3.27-10): تدرّج KL للتوزيعات المعطيات: q_θ. المطلوب: $\nabla_\theta D_{KL}(p\|q_\theta)$. الحل: الخطوة 1: $-\mathbb{E}_p[\nabla_\theta \ln q_\theta]$. النتيجة: تدرّج بسيط. الربط بالذكاء الاصطناعي: تدريب ن عبر KL.

مثال (3.27-11): قاعدة السلسلة المعطيات: توزيعات مشتركة. المطلوب: التفكيك. الحل: الخطوة 1: $D_{KL}(p(x,y)\|q(x,y)) = D_{KL}(p(x)\|q(x)) + \mathbb{E}_{p(x)} D_{KL}(p(y \mid x)\|q(y \mid x))$. النتيجة: تفكيك مفيد. الربط بالذكاء الاصطناعي: تحليل النماذج المتغيّرة.

مثال (3.27-12): فئوي عملي المعطيات: توزيع ملاحَظ 10 فئات. المطلوب: KL مع تنبّؤ النموذج. الحل: الخطوة 1: نحسب المجموع على الفئات العشر. النتيجة: رقم أداء. الربط بالذكاء الاصطناعي: مقارنة نماذج.

مثال (3.27-13): KL و MLE المعطيات: عيّنات من p. المطلوب: العلاقة. الحل: الخطوة 1: تقليل CE تجريبيّاً = تقليل KL تجريبيّاً $\Rightarrow$ MLE (من 18). النتيجة: تطابق نظري. الربط بالذكاء الاصطناعي: تبرير تدريب الشبكات.

مثال (3.27-14): عدم السلبية عدديّاً المعطيات: مثالين متباعدين. المطلوب: التحقّق. الحل: الخطوة 1: كلتا القيمتين موجبتان. النتيجة: تأكيد لجرم جيبس (4.27). الربط بالذكاء الاصطناعي: تحقّق من التنفيذ.

مثال (3.27-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: الدور. الحل: الخطوة 1: KL هو «اللغة المشتركة» للتدريب: تصنيف، توليد، تعزيز. النتيجة: مقياس مركزي. الربط بالذكاء الاصطناعي: أساس دوالّ الخسارة.

أخطاء شائعة

- الخلط بين $D_{KL}(p\|q)$ و $D_{KL}(q\|p)$.
- استخدام KL كمسافة هندسية (ليست مقياساً).
- السماح بأصفار في q فوق دعم p.
- نسيان أنّ KL لا تتبع متراجحة المثلّث.

$$D_{KL}(p\,\|\,q) \;\geq\; 0 \quad \text{(جيبس)}, \qquad X \to Y \to Z \implies I(X;Z) \leq I(X;Y) \tag{3.27}$$

مبرهنة جيبس (عدم السلبية):

$D_{KL}(p\|q) \geq 0$ والمساواة تكفيه ولا تكتفي $p = q$.

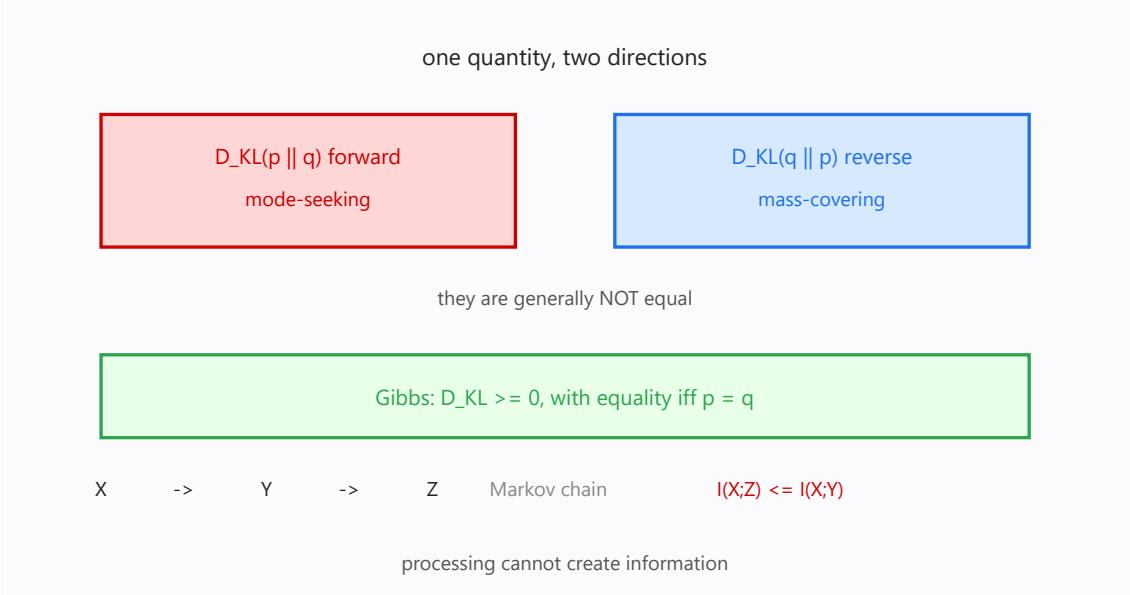
معالجة البيانات: إذا كان $X \to Y \to Z$ سلسلة ماركوف، فـ $I(X;Z) \leq I(X;Y)$.

جدول الرموز

الرمز	المعنى
$D_{KL} \geq 0$	متراجحة جيبس
ماركوف	تكييف (conditional independence)
$I(X;Z)$	معلومات متبادلة (من 26)
c, f	ثابت، دالّة قابلة للعكس

الرسم

<figure> الشكل<figcaption> 3.27: KL غير سالبة غير متماثلة؛ والمعالجة لا تزيد المعلومات.</figcaption>



شكل ٣.٢٧: *
خصائص KL: جيبس عدم التماثل ومعالجة البيانات

</figure>

البرهان (مخطّط)

جيبس: بما أنّ $-\log$ محدّبة، فبجنسن $\mathbb{E}_p[\log \frac{q}{p}] \leq \log \mathbb{E}_p[\frac{q}{p}] = \log \sum q = 0$. ماركوف: من سلسلة النسب $\frac{p(x)p(y|x)p(z|y)}{q(x)q(y|x)q(z|y)}$ بالجمع على y ثمّ z. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.27): متراجحة جيبس المعطيات: توزيعان p, q. المطلوب: الحدّ. الحل: الخطوة 1: $D_{KL}(p\|q) \geq 0$. النتيجة: لا تباعد سالب. الربط بالذكاء الاصطناعي: تبرير أنّ CE $\geq$ H.

مثال (27.4-2): الإثبات بجنسن المعطيات: $f = -\ln$ محدّبة. المطلوب: الخطوة الجوهريّة. الحل: الخطوة 1: $\mathbb{E}_p[f(\frac{q}{p})] \leq f(\mathbb{E}_p[\frac{q}{p}])$ (جنسن من 15). النتيجة: $f(1) = 0 \leq$. الربط بالذكاء الاصطناعي: أداة إثبات متكرّرة.

مثال (27.4-3): شرط المساواة المعطيات: $D_{KL} = 0$. المطلوب: ماذا نستنتج؟ الحل: الخطوة 1: $\frac{q}{p}$ ثابتاً على دعم p. النتيجة: تكافؤ (على الدعم). الربط بالذكاء الاصطناعي: المساواة تعني التطابق. $p = q \Rightarrow p$

مثال (27.4-4): عدم التماثل المعطيات: مثال 27.3-1 مقابل 2. المطلوب: المقارنة. الحل: الخطوة 1: القيمتان مختلفة. النتيجة: $D_{KL}(p\|q) \neq D_{KL}(q\|p)$. الربط بالذكاء الاصطناعي: انتبه لترتيب الوسائط.

مثال (27.4-5): ليس مقياساً المعطيات: نختبر $D_{KL}(p,r) \leq D_{KL}(p,q) + D_{KL}(q,r)$. المطلوب: هل تتحقّق؟ الحل: الخطوة 1: قد تتحقّق أحياناً، لكنّها ليست مبرهنة عامّة. الخطوة 2: لأنّها غير متماثلة. النتيجة: لا نعتمد عليها كمسافة. الربط بالذكاء الاصطناعي: تحذير في الخوارزميات المتقاربة.

مثال (27.4-6): معالجة البيانات المعطيات: $X \to Y \to Z$. المطلوب: النتيجة. الحل: الخطوة 1: $I(X;Z) \leq I(X;Y)$. النتيجة: المعالجة تفقد معلومات. الربط بالذكاء الاصطناعي: حدود الطبقات المخفية.

مثال (27.4-7): مثال على الماركوف المعطيات: صورة ← وصف ← نصّ. المطلوب: التطبيق. الحل: الخطوة 1: النصّ لا يحتوي معلومات عن الصورة أكثر من الوصف. النتيجة: حدّ عملي. الربط بالذكاء الاصطناعي: أنظمة متعدّدة الوسائط.

مثال (27.4-8): التكييف يزيد KL المعطيات: تكييف على Y. المطلوب: المتراجحة. الحل: الخطوة 1: $D_{KL}(p(x \mid y)\|q(x \mid y))$ تتوسّط لا تقلّ عموماً. الخطوة 2: لكن التوقّع الشرطي هو المتوسّط المرجّح. النتيجة: انتبه للنطق. الربط بالذكاء الاصطناعي: تحليل النماذج الشرطية.

مثال (27.4-9): الاستقلال يجمّع المعطيات: مستقلّان. المطلوب: KL؟ الحل: الخطوة 1: $D_{KL}(p_1p_2\|q_1q_2) = D_{KL}(p_1\|q_1) + D_{KL}(p_2\|q_2)$. النتيجة: جمع. الربط بالذكاء الاصطناعي: خسائر منفصلة تُجمع.

مثال (27.4-10): التحدّب في الزوج المعطيات: (p,q). المطلوب: طبيعة التحدّب. الحل: الخطوة 1: محدّبة في الزوج (مشتركة). النتيجة: تسهيل في التحسين. الربط بالذكاء الاصطناعي: ضمان تقارب التدريب.

مثال (27.4-11): CLT و KL المعطيات: p قياسي، q بتباين مختلفة. المطلوب: القيمة. الحل: الخطوة 1: نطبّق صيغة الغاوسي. النتيجة: رقم يدلّ على البعد. الربط بالذكاء الاصطناعي: مقارنة توزيعات كامنة.

مثال (27.4-12): عدم تغيّر KL كافياً المعطيات: q صفر غير مقبول. المطلوب: التفسير. الحل: الخطوة 1: إن كانت هناك حالة بـ $p > 0$ و $q = 0$ فلا نهائية. الخطوة 2: لكن $q > 0$ مقابل $p = 0$ لا يؤثّر. النتيجة: الشرط أحادي الاتجاه. الربط بالذكاء الاصطناعي: احتياط في softmax.

مثال (27.4-13): حدود الخلط المعطيات: $q = \lambda q_1 + (1-\lambda)q_2$. المطلوب: حدّ أعلى. الحل: الخطوة 1: $\leq \lambda D_{KL}(p\|q_1) + (1-\lambda)D_{KL}(p\|q_2)$ (محدّبية). النتيجة: تراكم. الربط بالذكاء الاصطناعي: تحليل المخاليط.

مثال (27.4-14): التخصيص المطلق للحدّ المعطيات: D_{KL} كافة أحجامها. المطلوب: التفسير. الحل: الخطوة 1: «عدد بتّات إضافية» للتعبير عن p بواسطة q. النتيجة: قراءة ترميزية. الربط بالذكاء الاصطناعي: تفسير جيبس هندسيّاً.

مثال (27.4-15): خلاصة المعطيات: كلّ الخصائص. المطلوب: القيمة. الحل: الخطوة 1: تجعل KL «لغة عامّة» للمقارنة. النتيجة: أساس نظري متين. الربط بالذكاء الاصطناعي: تطبيقات بلا حدود.

أخطاء شائعة

- استخدام KL كمسافة في خوارزميات مثل k-NN.
- نسيان اتجاه المراجع في التباعد.
- المبالغة في تفسير معالجة البيانات (انه حتمي لا «توقّع»).

- إغفال دعم الدعم (support mismatch).

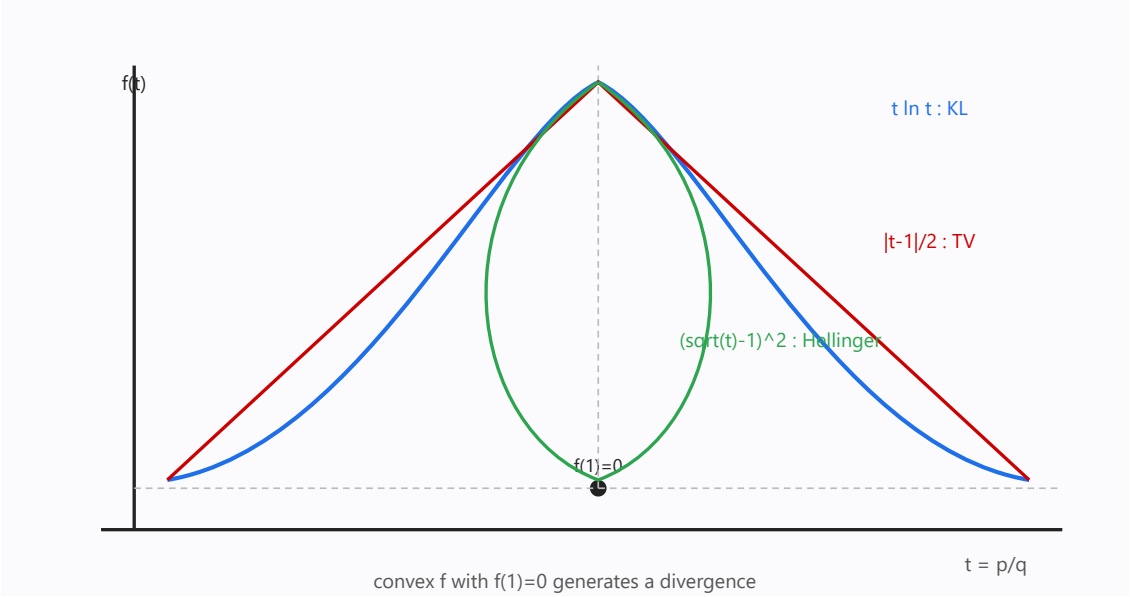
$$D_f(p\,\|\,q) \;=\; \sum_{x} q(x)\, f\!\left(\frac{p(x)}{q(x)}\right), \qquad f \text{ محدّبة و } f(1)=0 \tag{4.27}$$

جدول الرموز

الرمز	المعنى
f	مُولّد التباعد
$f(1)=0$	شرط التطابق
محدّبة	يضمن عدم السلبية
$t = p/q$	نسبة الكثافة

الرسم

<figure> الشكل<figcaption> 5.27: كلّ دالّة محدّبة بـ $f(1) \;=\; 0$ تولّد تباعداً، KL و TV و Hellinger كلّها



شكل ٤٠٢٧: *
تباعدات ف-ديفرجنس: عائلة المولدات

حالات خاصة.<figcaption/> </figure>

البرهان (مخطّط)

بجنسن: $D_f(p\|q) = \mathbb{E}_q[f(\tfrac{p}{q})] \geq f(\mathbb{E}_q[\tfrac{p}{q}]) = f(1) = 0$، لأنّ $\sum q\tfrac{p}{q} = \sum p = 1$. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.27): التعريف المعطيات: $t\ln t$ $=$ $f(t)$. المطلوب: أيّ تباعد؟ الحل: الخطوة 1: $= \sum q\frac{p}{q}\ln\frac{p}{q}$
النتيجة: $D_{KL}(p\|q)$. الربط بالذكاء الاصطناعي: KL حالة خاصّة. $\sum p\ln\frac{p}{q}$.
مثال (2-5.27): KL العكسي المعطيات: $-\ln t$ $=$ $f(t)$. المطلوب: النوع. الحل: الخطوة 1: $= \sum q(-\ln\frac{p}{q})$
النتيجة: $D_{KL}(q\|p)$. الربط بالذكاء الاصطناعي: اتجاه عكسي ممكن. $\sum q\ln\frac{q}{p}$.

مثال (3-5.27): المسافة الكلّية المعطيات: $f(t) = \frac{1}{2}|t-1|$. المطلوب: التباعد. الحل: الخطوة 1: $\frac{1}{2}\sum|p-q|$ = TV. النتيجة: Total Variation. الربط بالذكاء الاصطناعي: محدود بـ $[0,1]$ دائماً.

مثال (4-5.27): هيلينغر المعطيات: $f(t) = (\sqrt{t}-1)^2$. المطلوب: التباعد. الحل: الخطوة 1: $\sum q(\sqrt{p/q}-1)^2 = \frac{1}{2}\|(\sqrt{p}-\sqrt{q})\|^2$ بعد التبسيط. النتيجة: Hellinger. الربط بالذكاء الاصطناعي: متين أمام الشذوذ.

مثال (5-5.27): كاي-مربّع المعطيات: $f(t) = (t-1)^2$. المطلوب: النوع. الحل: الخطوة 1: $\chi^2(p,q) = \sum\frac{(p-q)^2}{q}$. النتيجة: تباعد كاي-مربّع. الربط بالذكاء الاصطناعي: يظهر في حدود التركيز.

مثال (6-5.27): جنسن-شانون المعطيات: f مركّب من KL مع الخليط. المطلوب: التعريف. الحل: الخطوة 1: $D_{JS} = D_{KL}(p\|m) + D_{KL}(q\|m)$ مع $m = \frac{p+q}{2}$. النتيجة: JS (هندسياً تباعد ف). الربط بالذكاء الاصطناعي: هدف GAN الكلاسيكي.

مثال (7-5.27): شروط f المعطيات: نريد تباعداً صالحاً. المطلوب: الشروط. الحل: الخطوة 1: $f(1) = 0$ و محدّبة. النتيجة: يكفي لضمان $D_f \geq 0$. الربط بالذكاء الاصطناعي: تصميم تباعدات جديدة.

مثال (8-5.27): عدم السلبية العامّة المعطيات: أيّ f محدّب. المطلوب: النتيجة. الحل: الخطوة 1: $D_f \geq 0$ (جنسن). النتيجة: برهان موحّد. الربط بالذكاء الاصطناعي: تبرير كلّ التباعدات.

مثال (9-5.27): f-GAN المعطيات: نماذج توليدية خصمية. المطلوب: الاستخدام. الحل: الخطوة 1: نخمّن T نقدياً بمميّز $\Rightarrow$ تعظيم حدّ تباييني لـ D_f. النتيجة: GAN بأيّ تباعد ف. الربط بالذكاء الاصطناعي: تصميم حديث لـ GAN.

مثال (10-5.27): التمثيل التبايني المعطيات: D_f لأيّ f. المطلوب: الصيغة. الحل: الخطوة 1: $\sup_T \mathbb{E}_p[T] - \mathbb{E}_q[f^*(T)]$ حيث f^* المترافق (من 5.22). النتيجة: صيغة لعب الخصم. الربط بالذكاء الاصطناعي: تدريب خصمي.

مثال (11-5.27): اختيار f للمتانة المعطيات: بيانات بشذوذ. المطلوب: الأفضل. الحل: الخطوة 1: Hellinger/TV أكثر متانة من KL الحادّ. النتيجة: اختيار واعٍ. الربط بالذكاء الاصطناعي: تدريب متين.

مثال (12-5.27): ألفا-تباعدات المعطيات: عائلة متماثلة بين KL الأمامي والعكسي. المطلوب: التعريف. الحل: الخطوة 1: D_α تعميم يربط بين الاتجاهين. النتيجة: مقايضة مخطّطة. الربط بالذكاء الاصطناعي: ضبط حساسية النموذج.

مثال (13-5.27): TV و KS المعطيات: توزيعان محدّدان. المطلوب: العلاقة. الحل: الخطوة 1: TV = أكبر فرق في الاحتمالات التراكمية. النتيجة: تفسير مباشر. الربط بالذكاء الاصطناعي: اختبارات الاختلاف.

مثال (14-5.27): JS و WGAN المعطيات: GAN بلا نواة. المطلوب: المشكلة. الحل: الخطوة 1: JS ينعدم تدرّجه عند توزيعين منفصلين $\Rightarrow$ تدرّجات شبه معدومة. الخطوة 2: Wasserstein يحلّ ذلك (الفصل 42). النتيجة: WGAN تقدّم مهمّ. الربط بالذكاء الاصطناعي: تطوّر نماذج التوليد.

مثال (15-5.27): خلاصة المعطيات: كلّ العائلة. المطلوب: القيمة. الحل: الخطوة 1: D_f إطار موحّد لخلق تباعدات بخصائص مرغوبة. النتيجة: أداة تصميم. الربط بالذكاء الاصطناعي: دوالّ خسارة جديدة.

أخطاء شائعة

- اختيار f غير محدّب فتظهر قيم سالبة.
- الخلط بين $D_{KL}(p\|q)$ و $D_{KL}(q\|p)$ في العائلة (مولّدان مختلفان).
- استخدام JS بلا وعي بتدرّجاته الشبه معدومة.
- اعتبار كلّ تباعدات ف مقياساً (ليست كذلك).

$$D_{KL}(p\|q) \;\geq\; \sup_{T} \Big(\mathbb{E}_p[T] - \log \mathbb{E}_q[e^T] \Big) \tag{5.27}$$

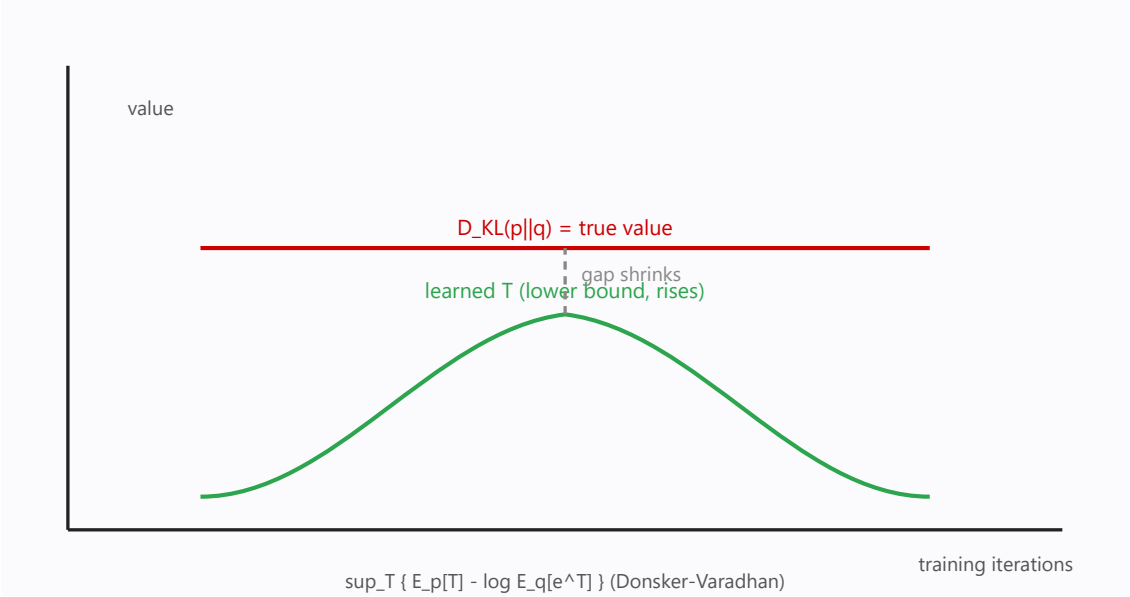
دونسكر-فارادهان (DV): هذا الحدّ (variational) يعطي تقديراً بلا مساعدة توزيع، ويكفيه شبكة عصبية T_ϕ.

جدول الرموز

الرمز	المعنى
T	دالّة مرشّحة (سنرى شبكة)
sup	نعلّم T لنعظّم الحدّ
e^T	أسّيها
MINE	تقدير MI بـ T تعليمي

الرسم

<figure> الشكل<figcaption> 6.27: نتعلّم دالّة T تعظّم الحدّ الأدنى؛ لا نحتاج كثافة معلومة.</figcaption>



شكل ٥.٢٧: *
الحدود التباينية لتقدير KL في بعد عال

</figure>

البرهان (مخطّط)

نطبّع: $\mathbb{E}_q[e^T] \leq \mathbb{E}_p[e^T]$ لأنّ $e^T > 0$ و $\sum p = e^T = 1$؛ بأخذ اللوغاريتم نحصل على (4.27) بعد إعادة الترتيب. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.27): صيغة DV المعطيات: p, q معلومتان. المطلوب: التحقّق. الحل: الخطوة 1: نختار $T = \ln(p/q)$. الخطوة 2: $\mathbb{E}_p[T] - \log \mathbb{E}_q[p/q] = D_{KL} - 0$. النتيجة: مساواة عند أفضل T. الربط بالذكاء الاصطناعي: الحدّ مشدود.

مثال (27.6-2): لماذا نحتاجه؟ المعطيات: بعد عالٍ وتوزيع مستمر. المطلوب: الخسارة. الحل: الخطوة 1: لتقدير كثافة $p(x)/q(x)$. الخطوة 2: نستدلّ بـ T من عيّنات. النتيجة: تقدير إلا منال. الربط بالذكاء الاصطناعي: MI في الشبكات العصبية.

مثال (27.6-3): MINE المعطيات: تقدير MI بين مخرجات شبكة وهدفها. المطلوب: الطريقة. الحل: الخطوة 1: نطبّق DV على p_{XY} و $p_X p_Y$ ثمّ نزداد على T_ϕ. الخطوة 2: حدّ تدرّج بقايا موجب. النتيجة: تقدير MI تعلّمياً. الربط بالذكاء الاصطناعي: بحث في التعلّم التمثيلي.

مثال (27.6-4): عيّنة القيمة المعطيات: دفعة N. المطلوب: تقدير الحدّ. الحل: الخطوة 1: $-\frac{1}{N}\sum T_\phi(x_i, y_i)$ $\log \frac{1}{N}\sum T_\phi(x_i, y_j)$ بخليط السلبي. النتيجة: فقدان قاعدة بيانات سالبي. الربط بالذكاء الاصطناعي: contrastive learning.

مثال (27.6-5): InfoNCE المعطيات: تقييم تباييني. المطلوب: الحدّ. الحل: الخطوة 1: $\text{MI} \geq \log K - \mathcal{L}_{\text{InfoNCE}}$ للنموذج الملتقط (انظر 7.27). النتيجة: ربط الرابح بالسالب. الربط بالذكاء الاصطناعي: CPC/SimCLR.

مثال (27.6-6): حدّ مشدود المعطيات: $T^\star = \ln(p/q)$. المطلوب: التحقّق. الحل: الخطوة 1: بطاقة الماء عند الفترة (27.6-1). النتيجة: لا فجوة. الربط بالذكاء الاصطناعي: ليس مجرّد حدّ تقريبي.

مثال (27.6-7): انحياز المقدّر المعطيات: T تعلّمت حتى الـ overfitting. المطلوب: المشكلة. الحل: الخطوة 1: الحدّ متحيّز إيجابياً. الخطوة 2: MINE يستخدم تصحيحاً لنزع هذا الميل. النتيجة: صعوبة عملية. الربط بالذكاء الاصطناعي: تحذير مهمّ.

مثال (27.6-8): التعقيد المعطيات: N عيّنات، بعد d. المطلوب: الصعوبة. الحل: الخطوة 1: تقدير MI في بعد عالٍ يحتاج $N \gg e^{MI}$. الخطوة 2: قابل للتحلّل بحاجة عينات أسّية. النتيجة: حدّ كمّي صعب. الربط بالذكاء الاصطناعي: حدود التعلّم التمثيلي.

مثال (27.6-9): تصحيح انحياز المقدّر المعطيات: طرق تصحيح. المطلوب: الأمثلة. الحل: الخطوة 1: الحالة المتأخّرة في MINE (recalls). النتيجة: تقدير أمتن. الربط بالذكاء الاصطناعي: تحسينات حديثة.

مثال (27.6-10): Target في GAN المعطيات: f_{GAN} كـ T. المطلوب: تمثيل متباييني. الحل: الخطوة 1: هدف GAN هو الحدّ التباييني لـ JS. النتيجة: توحيد نظري. الربط بالذكاء الاصطناعي: Nowozin et al. (2016).

مثال (27.6-11): RL المعطيات: أهداف خصمية في RL. المطلوب: الاستخدام. الحل: الخطوة 1: DV يبرّر معادلة Bellman الأمثل في التحديد. الخطوة 2: الروابط مع الاستدلال الاحتمالي. النتيجة: نظرة موحّدة. الربط بالذكاء الاصطناعي: deep RL.

مثال (27.6-12): المولّد مقابل المميّز المعطيات: GAN/VAE. المطلوب: المقارنة. الحل: الخطوة 1: VAE يعظّم ELBO (حدّ تباييني)؛ GAN يستخدم حدّاً تباينياً. الخطوة 2: كلاهما يتفادى حساب الكثافة. النتيجة: فلسفتان مختلفتان. الربط بالذكاء الاصطناعي: اختيار نموذج التوليد.

مثال (27.6-13): مراجعة ELBO المعطيات: D_{KL} غير قابل للتكامل. المطلوب: الحلّ. الحل: الخطوة 1: نستخدم هدف محدّب مثل $\mathbb{E}_q[\ln p(x,z)] + \log q(z)$. النتيجة: ELBO (الفصل 41). الربط بالذكاء الاصطناعي: VAE.

مثال (27.6-14): قياس الوفرة المعطيات: شبكة تعلّمت T. المطلوب: التقييم. الحل: الخطوة 1: نقارن $T_{\text{معلّم}}$ بـ $\ln(p/q)$ عند التوفّر. النتيجة: مقياس نوعية. الربط بالذكاء الاصطناعي: عمليّة.

مثال (27.6-15): خلاصة المعطيات: كلّ الحدود. المطلوب: القيمة. الحل: الخطوة 1: حوّل الكثافة إلى دالّة قابلة للتدريب $\Rightarrow$ قابل للتطبيق في بعد عالٍ. النتيجة: ثورة تطبيقية. الربط بالذكاء الاصطناعي: أساس البحث الحديث.

أخطاء شائعة

- نسيان تصحيح الانحياز فيفقد جدواه.

- الخلط بين MINE و DIM (variants).
- الاعتماد على MI كهدف وحيد دون انتظام.
- الظن أنّ الحدّ يتقارب دائماً بسرعة.

لمخرجات الدرجات z_k والتسمية y:

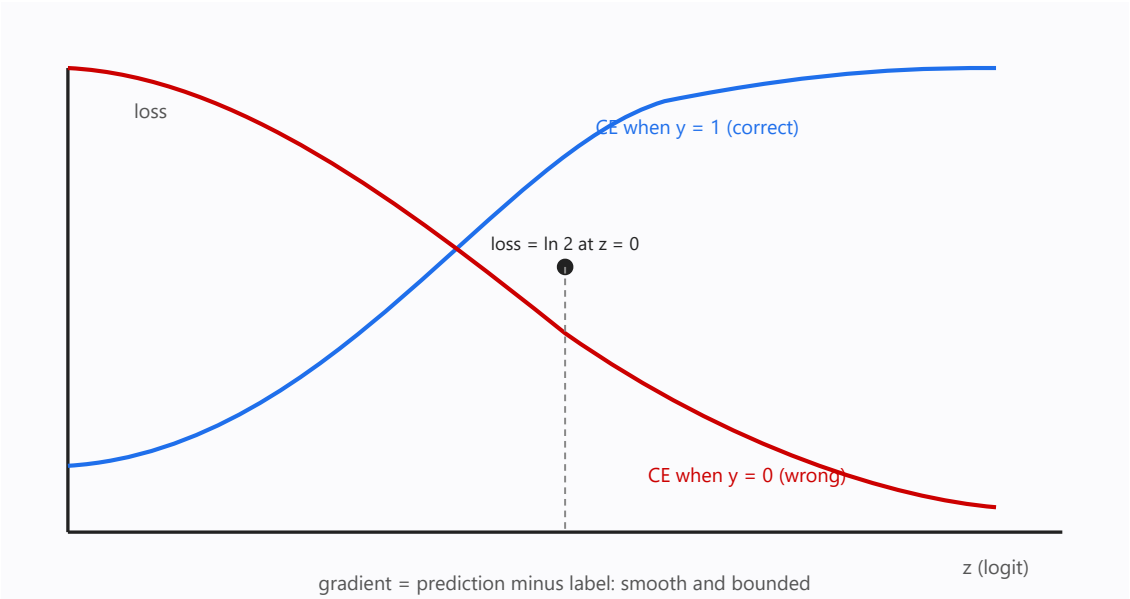
$$\mathcal{L}_{\text{CE}} = -\sum_{k=1}^{K} y_k \log \hat{y}_k, \qquad \hat{y}_k = \frac{e^{z_k}}{\sum_j e^{z_j}}, \qquad \nabla_z \mathcal{L} = \hat{y} - y \tag{6.27}$$

جدول الرموز

الرمز	المعنى
$\hat{y}$	مخرجات softmax
y	التسمية (واحد ساخن)
$\hat{y} - y$	التدرّج نحو الدرجات
T	درجة الحرارة (temperature)

الرسم

<figure> الشكل<figcaption> 7.27: softmax يحوّل الدرجات لتوزيع؛ الخسارة تقيس الفجوة عن



شكل ٦.٢٧: *
خسارة الإنتروبيا المتقاطعة مع softmax

التسمية.</figcaption> </figure>

البرهان (مخطّط)

باشتقاق مزدوج: $\partial \hat{y}_j / \partial z_k = \hat{y}_j(\delta_{jk} - \hat{y}_k)$، بالتعويض في $\mathcal{L}$ نحصل على $\hat{y}_k - y_k$ (برهان تفصيلي في 6.9). ■

خمسة عشر مثالاً محلولاً

مثال (27.7-1): التدرّج = الباقي المعطيات: $\hat{y} = (0.7, 0.2, 0.1)$، $y = (1, 0, 0)$. المطلوب: ∇_z. الحل: الخطوة 1: $\hat{y} - y = (-0.3, 0.2, 0.1)$. النتيجة: التدرّج يصرّف الدرجة الأولى للأعلى. الربط بالذكاء الاصطناعي: معنى التحديث.

مثال (27.7-2): تنبؤ صحيح المعطيات: $\hat{y} = (0.9, 0.1)$، $y = (1, 0)$. المطلوب: الخسارة. الحل: الخطوة 1: $-\ln 0.9 \approx 0.105$. النتيجة: 105.0 نات. الربط بالذكاء الاصطناعي: عقوبة خفيفة على واثق صحيح.

مثال (27.7-3): تنبؤ خاطئ واثق المعطيات: $\hat{y} = (0.1, 0.9)$، $y = (1, 0)$. المطلوب: الخسارة. الحل: الخطوة 1: $-\ln 0.1 \approx 2.303$. النتيجة: 303.2 نات (عقوبة كبيرة). الربط بالذكاء الاصطناعي: ثقة خاطئة مُكلّفة.

مثال (27.7-4): تنبؤ متردّد المعطيات: $\hat{y} = (0.5, 0.5)$، $y = (1, 0)$. المطلوب: الخسارة. الحل: الخطوة 1: $-\ln 0.5 = 0.693$. النتيجة: 693.0 نات. الربط بالذكاء الاصطناعي: قيمة متوسّطة بين الحالتين.

مثال (27.7-5): الثبات العددي المعطيات: درجات كبيرة ($z = 1000$). المطلوب: الخطر. الحل: الخطوة 1: e^{1000} يفيض. الخطوة 2: نطرح $\max z$ قبل الأسّي (log-sum-exp) من 7.6). النتيجة: softmax مستقرّ. الربط بالذكاء الاصطناعي: جودة التنفيذ.

مثال (27.7-6): ثقة النموذج المعطيات: طبقة softmax. المطلوب: تفسير الإخراج. الحل: الخطوة 1: التوزيع يشير لثقة؛ CE تعاقب عدم التطابق. النتيجة: قراءة صحيحة. الربط بالذكاء الاصطناعي: تفسير النتائج.

مثال (27.7-7): انحدار لوجستي المعطيات: نفس الخسارة مع $K = 2$. المطلوب: النتيجة. الحل: الخطوة 1: خسارة لوجستية = CE ثنائية. النتيجة: توحيد. الربط بالذكاء الاصطناعي: كلّ المصنّفات.

مثال (27.7-8): لماذا CE لا MSE؟ المعطيات: مقارنة التدرّجات. المطلوب: الفرق. الحل: الخطوة 1: CE تدرّجها $\hat{y} - y$ بلا انحراف $4\hat{y}(1-\hat{y})$ من MSE. الخطوة 2: CE لا تتجمّد عند $\hat{y}$ الطرفي. النتيجة: تعلّم أسرع وأقوى. الربط بالذكاء الاصطناعي: قاعدة عملية.

مثال (27.7-9): توزيع متعدّد المعطيات: نرمي حجر نرد 10 فئات. المطلوب: التدرّج. الحل: الخطوة 1: $-\log \hat{y}_k \sum$ للتسمية. النتيجة: خسارة عشرة أصناف. الربط بالذكاء الاصطناعي: تصنيف واسع.

مثال (27.7-10): العلم الطري المعطيات: نريد توزيعات ملطّفة. المطلوب: نوع التسمية. الحل: الخطوة 1: تنعيم (smoothing) بدل واحد ساخن. الخطوة 2: لا نثق 100٪ ⇐ انحياز أقلّ. النتيجة: تعميم أفضل. الربط بالذكاء الاصطناعي: smoothing label. (Inception)

مثال (27.7-11): وزن الفئات المعطيات: فئة نادرة. المطلوب: دفعها للأعلى. الحل: الخطوة 1: نضرب خسارتها بمعامل $\alpha_k > 1$. النتيجة: توازن. الربط بالذكاء الاصطناعي: imbalanced data.

مثال (27.7-12): الانفجار المتدرّج المعطيات: 4 طبقات. المطلوب: لماذا CE تستقرّ؟ الحل: الخطوة 1: تدرّجها محلياً محدود لأنّ $\hat{y} \in (0, 1)$. الخطوة 2: والتوزيع يقترب من الهدف. النتيجة: سلاسة تدريب. الربط بالذكاء الاصطناعي: سلاسة التعلّم.

مثال (27.7-13): معايرة درجة الحرارة المعطيات: نريد معايرة الثقة. المطلوب: الدور. الحل: الخطوة 1: نطبّع الدرجات قبل softmax. الخطوة 2: T يتحكّم بحدّة الثقة بلا تغيير التصنيف. النتيجة: معايرة الثقة. الربط بالذكاء الاصطناعي: تقييم جودة الثقة.

مثال (27.7-14): تقطير المعرفة المعطيات: مدرّس كبير. المطلوب: توزيعه الهدف. الحل: الخطوة 1: نعطّي توزيعات مدرّسة كأهداف ناعمة. الخطوة 2: الطالب يتعلّم من T الـ softmax المرفوع. النتيجة: تعلّم بـ «صناعة» أكبر. الربط بالذكاء الاصطناعي: knowledge distillation.

مثال (27.7-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: القيمة. الحل: الخطوة 1: softmax+CE ثنائي متآزر، تدرّج بسيط، ثبات عددي، قابلية تفسير. النتيجة: العمود الفقري للتصنيف. الربط بالذكاء الاصطناعي: أساس تدريب النماذج.

أخطاء شائعة

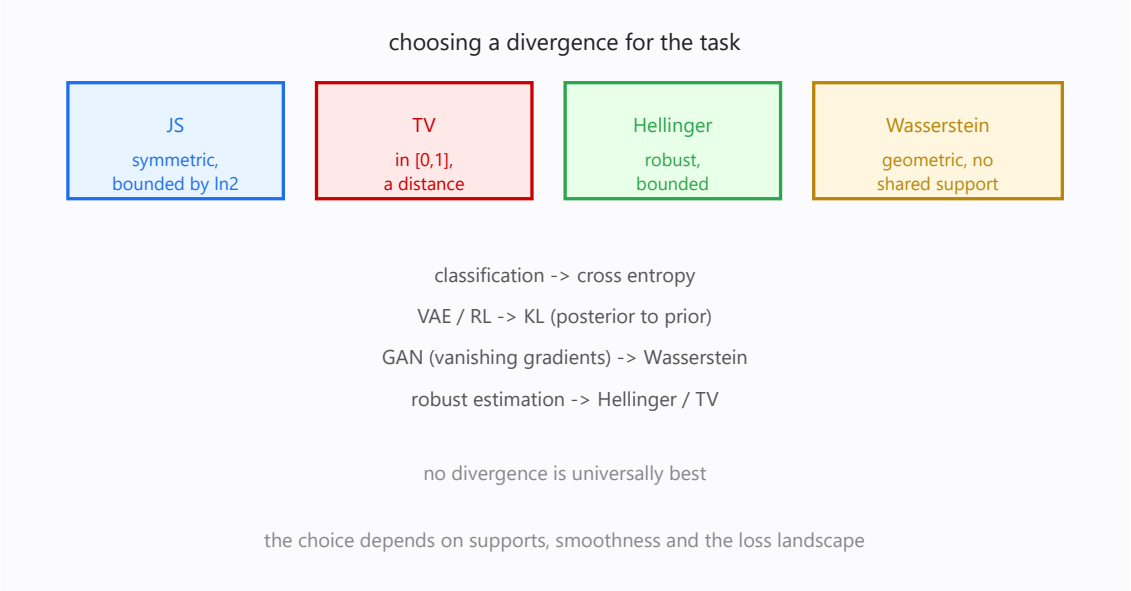
- حساب softmax بلا خصم الحدّ الأقصى.
- استخدام MSE عمداً بظنّه أقرب «دقّة».
- نسيان أن y توزيعٌ واحد ساخن والأنواع الأخرى ممكنة.
- تجاهل درجات الحرارة في التقطير.

$$D_{JS}(p\|q) = \tfrac{1}{2}D_{KL}(p\|m) + \tfrac{1}{2}D_{KL}(q\|m), \quad m = \tfrac{p+q}{2}, \qquad \mathrm{TV} = \tfrac{1}{2}\|p-q\|_1 \tag{7.27}$$

الرمز	المعنى
D_{JS}	جنسن-شانون
m	خليط التوزيعين
TV	المسافة الكلّية
W_1	Wasserstein-1 (الفصل 42)

الرسم

<figure> الشكل<figcaption> 8.27: JS و TV و Hellinger متناظرة ومحدودة؛ Wasserstein يعتمد على الهندسة



شكل ٧.٢٧: *
مقارنة تباعدات JS و TV و Hellinger و Wasserstein

لا الكثافة.</figcaption> </figure>

البرهان (مخطّط)

JS متماثل بحكم التعريف، ومحدود بـ $\ln 2$ (بتات ≤ 1) لأنّ $D_{KL}(p\|m) \leq \ln 2$ طولاً. TV = أكبر فرق احتمالي في $[0,1]$. Wasserstein مقياس هندسي لا يعتمد على الكثافة $\Rightarrow$ يعمل عند توزيعين بلا تقاطع. $\Rightarrow$ ■

خمسة عشر مثالاً محلولاً

مثال (27.8-1): JS المتماثل المعطيات: توزيعان. المطلوب: التحقّق. الحل: الخطوة 1: بتبديل p, q لا يتغيّر الناتج (بالتعريف). النتيجة: متماثل. الربط بالذكاء الاصطناعي: خسارة GAN الكلاسيكية.

مثال (27.8-2): JS محدود المعطيات: أيّ p, q. المطلوب: الحدّ. الحل: الخطوة 1: $D_{JS} \le \ln 2$ (أي 1 بت). الخطوة 2: يبلغه عند توزيعين منفصلين تماماً. النتيجة: حدّ نظري واضح. الربط بالذكاء الاصطناعي: سلّم ثابت للخسارة.

مثال (27.8-3): JS من توزيعين متطابقين المعطيات: $p = q$. المطلوب: القيمة. الحل: الخطوة 1: $D_{JS} = 0$. النتيجة: صفر. الربط بالذكاء الاصطناعي: الأمثلية.

مثال (27.8-4): JS دورت على منفصلين المعطيات: $p \perp q$ (بلا تداخل). المطلوب: D_{JS}. الحل: الخطوة 1: عند الحدّ $\ln 2$. الخطوة 2: لكن التدرّج يقترب من الصفر. النتيجة: مشكلة GAN الأولى. الربط بالذكاء الاصطناعي: صعوبة التدريب.

مثال (27.8-5): TV غير محدود بالتكوين المعطيات: p, q منفصلان. المطلوب: TV. الحل: الخطوة 1: $\frac{1}{2}(1+1) = 1$ (الأقصى). النتيجة: «أبعد ما يمكن». الربط بالذكاء الاصطناعي: حدّ واضح لكشف الانحراف.

مثال (27.8-6): TV كأكبر فروق المعطيات: دوالّ تراكمية. المطلوب: التفسير. الحل: الخطوة 1: $\sup_x |F_p(x) - F_q(x)|$. (KS) الخطوة 2: KS = TV في بعد واحد (على $\mathbb{R}$). النتيجة: قابل للقياس مباشرة. الربط بالذكاء الاصطناعي: اختبار كولموغوروف-سميرنوف.

مثال (27.8-7): Hellinger و TV المعطيات: توزيعان. المطلوب: العلاقة. الحل: الخطوة 1: $\frac{1}{2}H^2 \le TV \le H\sqrt{1 - \frac{1}{4}H^2}$ حيث H^2 هيلينغر مربّع. النتيجة: ترابط كمّي. الربط بالذكاء الاصطناعي: حدود متبادلة مفيدة.

مثال (27.8-8): Wasserstein المعطيات: تكلفة النقل. المطلوب: التعريف. الحل: الخطوة 1: أقلّ تكلفة لنقل كتلة p إلى q (الفصل 42). الخطوة 2: لا يستلزم دعامة مشتركة. النتيجة: خيار قوي للتوليد. الربط بالذكاء الاصطناعي: WGAN.

مثال (27.8-9): تدرّجات TV المعطيات: TV تدرّجها محدود. المطلوب: النتيجة. الحل: الخطوة 1: نعم، محدود بـ 2. الخطوة 2: لكن يختفي عند التطابق التامّ. النتيجة: سلوك محدود لكنه يتلاشى. الربط بالذكاء الاصطناعي: مقارنة.

مثال (27.8-10): Wasserstein تدرّج المعطيات: W في توزيعين قريبين. المطلوب: السلوك. الحل: الخطوة 1: يتناسب مع المسافة (تقريباً خطّي). الخطوة 2: تدرّج مفيد حتى عند الاختلاف الكبير. النتيجة: ميزة على JS. الربط بالذكاء الاصطناعي: سبب نجاح WGAN.

مثال (27.8-11): كاي-مربّع المعطيات: $\chi^2(p, q)$. المطلوب: السلوك. الحل: الخطوة 1: غير محدود. الخطوة 2: يهتم بالمناطق ذات q صغير. النتيجة: حسّاس. الربط بالذكاء الاصطناعي: اختيار متخصّص.

مثال (27.8-12): جدول الخصائص المعطيات: خمسة تباعدات. المطلوب: المقارنة. الحل: الخطوة 1: حدّد لكلّ منها: متماثل؟ محدود؟ يتلاشى تدرّجه؟ يحتاج تقاطع دعامة؟ النتيجة: دليل اختيار. الربط بالذكاء الاصطناعي: قرار تصميم.

مثال (27.8-13): أيّ تباعد للتصنيف؟ المعطيات: مصنّف عميق. المطلوب: الاختيار. الحل: الخطوة 1: الإنتروبيا المتقاطعة (= KL مع الحقيقة). النتيجة: معيار التصنيف. الربط بالذكاء الاصطناعي: قرار واضح.

مثال (27.8-14): أيّ تباعد للتوليد؟ المعطيات: GAN/VAE. المطلوب: الاختيار. الحل: الخطوة 1: WGAN عموماً أفضل من JS الكلاسيكي في التوليد. النتيجة: مقارنة تطبيقية. الربط بالذكاء الاصطناعي: تطوّر GAN.

مثال (27.8-15): خلاصة المعطيات: كلّ التباعدات. المطلوب: القاعدة. الحل: الخطوة 1: لا يوجد تباعد «أفضل» مطلقاً؛ يعتمد على المهمّة. النتيجة: اختيار واعٍ. الربط بالذكاء الاصطناعي: حكمة هندسية.

أخطاء شائعة

- افتراض أنّ JS مقياس (ليس كذلك).

- استخدام JS في بيئات توزيعين بلا تقاطع.
- الخلط بين TV و KL (سلوك تدرّج مختلف).
- الظن أنّ Wasserstein يحلّ كلّ مشاكل التوليد.

ملخّص النظريات

النظرية	المفهوم	الأهمّية
1.27 CE	$H(p,q) = H(p) + D_{KL}$	خسارة التصنيف
2.27 KL	$\mathbb{E}_p[\log \frac{p}{q}]$	مطابقة التوزيعات
3.27 الخصائص	$D_{KL} \geq 0$ (جيبس), معالجة البيانات	ضمانات نظرية
4.27 ف-ديفرجنس	$D_f = \mathbb{E}_q[f(p/q)]$	عائلة موحّدة
5.27 الحدود	$\sup_T(\mathbb{E}_p T - \log \mathbb{E}_q e^T)$	تقدير عالي البعد
6.27 تكسارة CE	$\hat{y} - y$	CE + softmax
7.27 المقارنة	JS/TV/Hellinger/W	اختيار الوظيفة

عشرون تمريناً (مع إجابات مختصرة)

١. صيغة CE؟ $(-\sum p \log q)$

٢. علاقة CE بـ KL؟ $(H(p,q) = H(p) + D_{KL}(p\|q))$

٣. صيغة KL؟ $(\sum p \log \frac{p}{q})$

٤. متى $D_{KL} = 0$؟ (عند $p = q$ على الدعم)

٥. هل KL متماثل؟ (لا)

٦. هل KL مقياس؟ (لا، لا تحقّق المثلّث)

٧. صيغة KL لغاوسيين؟ $(\ln \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2})$

٨. D_{KL} الأمامي يسعى لـ؟ (القمم)

٩. صيغة TV؟ $(\frac{1}{2}\|p - q\|_1)$

١٠. صيغة Hellinger المربّع؟ $(\frac{1}{2}\sum(\sqrt{p} - \sqrt{q})^2)$

١١. مولّد KL؟ $(f(t) = t \ln t)$

١٢. صيغة JS؟ $(\frac{1}{2}D_{KL}(p\|m) + \frac{1}{2}D_{KL}(q\|m))$

١٣. حدّ JS؟ $(\ln 2)$

١٤. صيغة الحدّ التبايني؟ $(\sup_T(\mathbb{E}_p T - \log \mathbb{E}_q e^T))$

١٥. ما دالّة DV المثلى؟ $(T^\star = \ln \frac{p}{q})$

١٦. تدرّج softmax+CE؟ $(\hat{y} - y)$

١٧. صيغة softmax؟ $(e^{z_k} / \sum_j e^{z_j})$

١٨. ماذا يضيف درجة الحرارة؟ (ليناً في التوزيع)

١٩. لماذا CE في التصنيف؟ (تدرّج قوي وبسيط)

٢٠. خطأ JS في التوليد؟ (تدرّجات شبه معدومة عند الانفصال)

فهرس الرموز

الرمز	المعنى
$H(p, q)$	إنتروبيا تقاطع
D_{KL}	تباعد KL
D_f	تباعد ف
D_{JS}, TV, H	جنسن-شانون، TV، هيلينغر
W_1	Wasserstein-1
$\hat{y}, y$	التنبؤ والتسمية

مراجع

- Thomas & Cover — *Elements of Information Theory* (الفصول 2 و8).
- Wu & Polyanskiy — *Lecture Notes on Information Theory*.
- Nowozin et al. — «f-GAN: Training Generative Neural Samplers using Variational Divergence Minimization» (NeurIPS 2016).
- Belghazi et al. — «MINE: Mutual Information Neural Estimation» (2018).
- Hinton, Vinyals & Dean — «Distilling the Knowledge in a Neural Network» (2015).
- Arjovsky, Chintala & Bottou — «Wasserstein GAN» (2017).

خاتمة: الفصل 28 ينقل هذه المقاييس إلى **السعة والترميز ومبدأ الوصف الأقصر**، حيث تصبح الإنتروبيا حدّاً فيزيائيّاً للضغط والتواصل.

السعة، الترميز، ومبدأ الوصف الأقصر

«الضغط ليس خداعاً؛ إنّه اكتشاف لما لا يستحقّ البقاء.»

بهذا الفصل نكمل الجزء الخامس. الفصل 26 أعطانا الإنتروبيا، و27 حوّلها إلى تباعدات. هذا الفصل يعطيها **معنى فيزيائيّاً**: الإنتروبيا هي الحدّ الأدنى لعدد البتّات اللازمة لتمثيل المصدر، والسعة هي الحدّ الأقصى لمعدّل النقل الموثوق عبر قناة صاخبة، ومبدأ الوصف الأقصر (MDL) يجعل هذه الحدود معياراً لاختيار النماذج في تعلّم الآلة.

سبع نظريات:

- **2.28 الترميز المصدري وحدّ شانون** — لا ننزل تحت الإنتروبيا.
- **3.28 سعة القناة** — مبرهنة شانون الثانية.
- **4.28 ترميز هافمان** — تحسين مباشر ومثلى.
- **5.28 الترميز الحسابي** — احتواء الرموز بفاعلية أعلى.
- **6.28 متراجحة كرافت** — لماذا تعمل الأكواد الفوريّة.
- **7.28 معدّل–تشويه** — التخلي عن الدقّة مقابل البتّات.
- **8.28 مبدأ الوصف الأقصر** — MDL وعلاقته بالتعميم.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى
$\ell(x)$	طول ترميز الرمز x
L	الطول المتوقّع للترميز
C	سعة القناة (بت/رمز)
D	تشويه متوسط مسموح
H	إنتروبيا (من 26)
n	طول السلسلة

نلتزم بالبتّات (أساس 2).

مبرهنة الترميز المصدري:

لكلّ ترميز وحديّ (uniquely decodable) فوريّ الطول:

$$L = \sum_{x} p(x)\,\ell(x) \;\geq\; H(X), \qquad L \;<\; H(X) + 1 \text{ دائمًا ممكن} \tag{1.28}$$

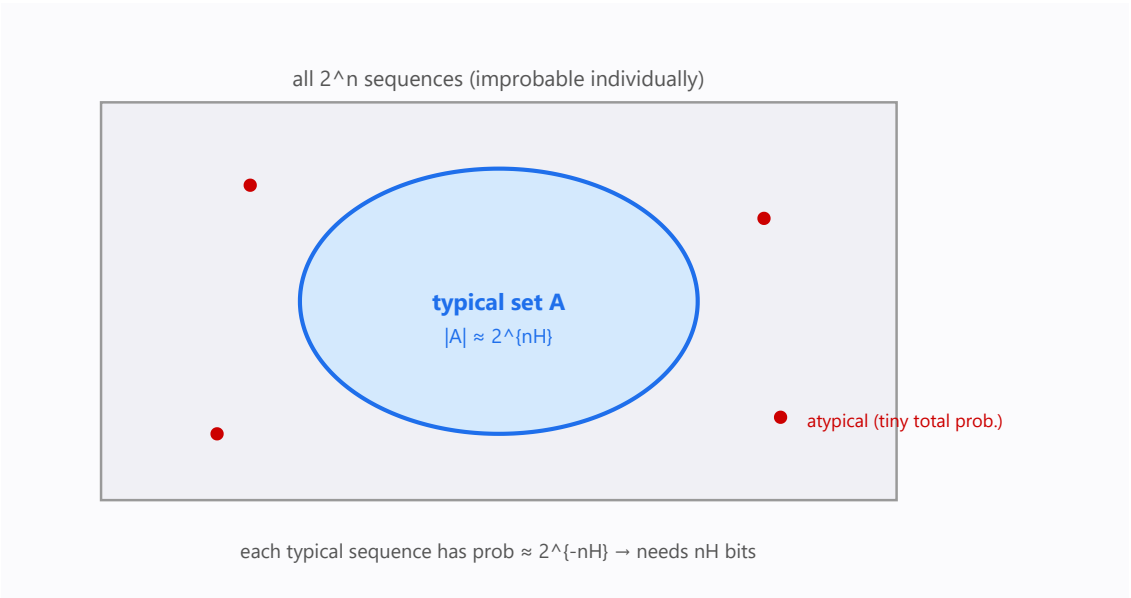
وبترميز نطاقات (block coding) على n رمزاً: $L/n \geq H$، ويمكن تقريبها من الأعلى بلا حدود.

جدول الرموز

الرمز	المعنى
فوري (prefix-free)	لا شيفرة بادئة لأخرى
فريد فكّ الترميز	لا لبس في فكّ الشيفرة
L/n	معدّل البتّات لكلّ رمز
مجموعة نموذجيّة	تسلسلات «شائعة» (AEP)

الرسم

<figure> الشكل<figcaption> 1.28: لسلسلة طويلة، تتراكم الاحتمالات في مجموعة نموذجيّة بحجم 2^{nH} $\approx$؛ تُرمّز



شكل ١.٢٨: *
الترميز المصدري: مجموعة النماذج

وفيرة فقط.<figcaption/> </figure>

البرهان (مخطّط)

نطبّق متراجحة كرافت (6.28) التي تعطي $\sum 2^{-\ell(x)} \le 1$؛ ثمّ جنسن على $\sum p 2^{-\ell+D}$ يعطي $H \le L$. الجانب الإيجابي يأتي من الترميز النطاقي على مجموعة المجموعات النموذجيّة (الدليل الكامل في Cover & Thomas). ■

خمسة عشر مثالاً محلولاً

مثال (1-2.28): حدّ الإنتروبيا المعطيات: $H(X) = 1.5$ بت. المطلوب: أقلّ طول متوقّع. الحل: الخطوة 1: $L \ge 1.5$ بت. النتيجة: لا يمكن أقلّ. الربط بالذكاء الاصطناعي: الحدّ النظري للضغط.

مثال (2-2.28): ترميز بطول ثابت المعطيات: 8 رموز متساوية. المطلوب: L. الحل: الخطوة 1: 3 بتّات لكلّ رمز. الخطوة 2: $H = \log_2 8 = 3$. النتيجة: $L = 3 = H$ (أمثل). الربط بالذكاء الاصطناعي: ASCII/binary مثالي للمتساوي.

مثال (3-2.28): الانحياز الأحادي المعطيات: 4 رموز باحتمالات $(0.7, 0.1, 0.1, 0.1)$. المطلوب: مدّة مثاليّة. الحل: الخطوة 1: $H = -0.7\log_2 0.7 - 3(0.1\log_2 0.1) \approx 0.360 + 0.996 = 1.356$. الخطوة 2: بأطول شيفرة ثابتة (2 بت) نهدر. النتيجة: نستخدم هافمان. الربط بالذكاء الاصطناعي: ضغط بيانات منحازة.

مثال (28.2-4): مجموعة نموذجية المعطيات: $n = 100$، $H = 0.5$. المطلوب: حجمها النسبي. الحل: الخطوة 1: $2^{nH} = 2^{50}$ تسلسلاً نموذجياً. النتيجة: قليل بين 2^{100}. الربط بالذكاء الاصطناعي: لماذا اللغة قابلة للضغط.

مثال (28.2-5): اللغة المعطيات: 3.1 بت/حرف. المطلوب: المتوقّع. الحل: الخطوة 1: $1.3 \approx$ بت لكلّ حرف أقلّ من 5 بتّات. الخطوة 2: الضغط يرصد البنية. النتيجة: توفير كبير. الربط بالذكاء الاصطناعي: ضغط النصوص قبل النقل.

مثال (28.2-6): ملف أصفار المعطيات: مليون بتّ أصفار. المطلوب: H والترميز. الحل: الخطوة 1: $H = 0$. الخطوة 2: الترميز يحتاج بضعة بتّات وصفية فقط. النتيجة: ضغط شبه كامل. الربط بالذكاء الاصطناعي: الأوزال المتناثرة/ encoding، run-length

مثال (28.2-7): العشوائي التامّ المعطيات: كلّ بتّ بـ $p = 0.5$. المطلوب: H والضغط. الحل: الخطوة 1: $H = 1$ لكلّ بتّ. الخطوة 2: لا ضغط ممكن. النتيجة: حدّ مطلق. الربط بالذكاء الاصطناعي: ضجيج/تشفير max ،entropy

مثال (28.2-8): إنتروبيا فعلية للملفّ المعطيات: احصِ تتابعات بايت. المطلوب: طريقة عملية الحل: الخطوة 1: $H =$ معدّل المعلومات على مستوى الرموز أو النوافذ. الخطوة 2: تقدير أعلى البايت لا يكشف البنية الأطول. النتيجة: دقّة أعلى. الربط بالذكاء الاصطناعي: ضغط كامل النطاق.

مثال (28.2-9): ضغط صور المعطيات: انحياز منخفض التردّد. المطلوب: التفعيل الحل: الخطوة 1: نحوّل لمجال يركّز الطاقة ،(DCT/wavelet) الخطوة 2: الكثافة عالية في قيم قليلة. النتيجة: ضغط قويّ ،(JPEG) الربط بالذكاء الاصطناعي: معالجة الصور.

مثال (28.2-10): ضغط صوت المعطيات: كلام بحدوث ذروة في تردّدات. المطلوب: التقنية الحل: الخطوة 1: ترميز تنبّئي يعتمد على نمط الكلام. النتيجة: MP3/AAC. الربط بالذكاء الاصطناعي: ترميز الأصوات.

مثال (28.2-11): القيمة العلوية المعطيات: نريد $H + 1$ لكلّ رمز. المطلوب: ما هو؟ الحل: الخطوة 1: ترميز طوله وحيد: نمدّد إلى كتلة $n \Rightarrow H \rightarrow$. النتيجة: تفوق محدود يقترب للصفر. الربط بالذكاء الاصطناعي: لماذا نرمّز نطاقات لا رموزاً.

مثال (28.2-12): المقارنة بين ترميزات المعطيات: ترميمان بطول 2 و 6.1 بت. المطلوب: التحليل الحل: الخطوة 1: لو $H = 1.2$ فالثاني أقرب لكن ليس مثالياً. النتيجة: فجوة 4.0 بت. الربط بالذكاء الاصطناعي: فحص جودة المرمّز.

مثال (28.2-13): إنتروبيا تكرارية المعطيات: سلسلة ذات رموز مرتبطة. المطلوب: المعدّل الحل: الخطوة 1: نستخدم إنتروبيا مشروطة (3.26) لا حاشويّة. الخطوة 2: $\frac{1}{n}H(X^n)$ ينزل لما دون H. النتيجة: ضغط أعمق. الربط بالذكاء الاصطناعي: نماذج ماركوف للضغط.

مثال (28.2-14): استخدامات التشفير المعطيات: نصّ عشوائي. المطلوب: هل يمكن ضغطه؟ الحل: الخطوة 1: لا؛ أيّ «ضغط» يضخّم. النتيجة: يكشف أنّ البيانات عشوائية. الربط بالذكاء الاصطناعي: تشخيص الضوْغطيّة.

مثال (28.2-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: القيمة الحل: الخطوة 1: الإنتروبيا هي «السعر الأدنى» للتعبير. النتيجة: حدّ فيزيائي للضغط. الربط بالذكاء الاصطناعي: تصميم التمثيلات.

أخطاء شائعة

- توقّع ضغط بيانات فيروسيّة عشوائية.
- حساب H بإزالة التراكيب (هامشية فقط).
- نسيان فرق الطول الثابت والعرضي.
- الخلط بين $L \geq H$ و $L < H + 1$ (تاريخان مختلفان).

لقناة منفصلة بلا ذاكرة يحدّدها احتمال الانتقال $p(y \mid x)$:

$$C = \max_{p(x)} I(X;Y) \qquad \text{(بتّ لكلّ استخدام للقناة)} \tag{2.28}$$

مبرهنة الترميز القناي (شانون الثانية):

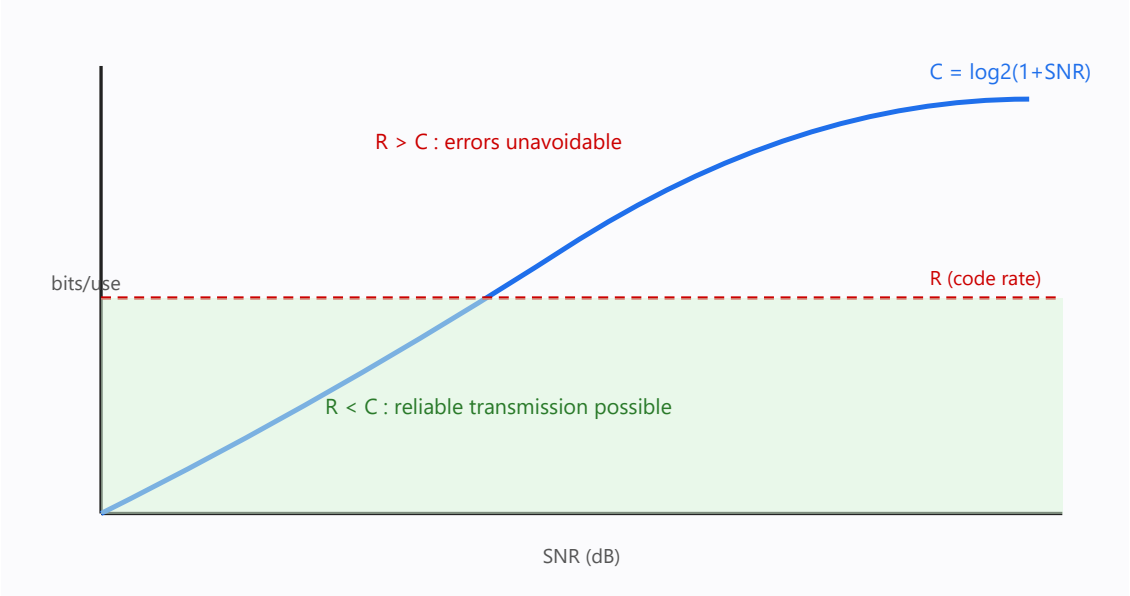
النقل الموثوق ممكن $R < C$ ffi، ومستحيل لأيّ $R > C$.

جدول الرموز

الرمز	المعنى
C	السعة
R	معدّل المعلومات المرسلة
$p(y \mid x)$	مصفوفة القناة
B	عرض الحزمة، S/N نسبة الإشارة للضجيج

الرسم

<figure> الشكل<figcaption> 2.28: تحت C يمكن تصحيح الخطأ إلى الصفر؛ فوقه يتراكم الخطأ حتميّاً.</figcaption>



شكل ٢٠٢٨: *
سعة القناة: أقصى معدل موثوق

</figure>

البرهان (مخطّط)

إثبات شانون يستخدم أعداداً نموذجيّة مشتركة: هناك 2^{nI} $\approx$ مخطّطات مرسلة مميّزة، وكلٌّ منها يقع في سحابة استقبال منفصلة. نختار 2^{nR} مخطّطاً مع تشفير عشوائي، وبالتالي $R < I \approx C$ يعطي خطأ يقترب من الصفر. ■

خمسة عشر مثالاً محلولاً

مثال (28.3-1): قناة مثالية المعطيات: $Y = X$ بلا ضوضاء. المطلوب: C. الحل: الخطوة 1: $I(X;Y) = H(X)$؛ عند الحدّ الأقصى $C \le \log |\mathcal{X}|$. النتيجة: $\log |\mathcal{X}|$. الربط بالذكاء الاصطناعي: قناة مثاليّة (تخزين).

مثال (28.3-2): قناة صاخبة ثنائية المعطيات: احتمال قلب $p = 0.1$. المطلوب: C. الحل: الخطوة 1: $C = 1 + p\log_2 p + (1-p)\log_2(1-p)$. الخطوة 2: $1 - 0.332 - 0.137 = 0.531 = 0.9(-0.152) + 0.1(-3.32) + 1$. النتيجة: ≈ 0.531 بت. الربط بالذكاء الاصطناعي: قناة اتصال أساسية.

مثال (28.3-3): قناة عشوائية تامّة المعطيات: $p = 0.5$ (قلب عادل). المطلوب: C. الحل: الخطوة 1: $C = 0$. النتيجة: لا معلومة تُنقل. الربط بالذكاء الاصطناعي: ضوضاء مُدمِّرة للمعلومة.

مثال (28.3-4): صيغة شannon–هارتلي المعطيات: عرض حزمة B، نسبة إشارة/ضجيج S/N. المطلوب: C. الحل: الخطوة 1: $C = B\log_2(1 + S/N)$. الخطوة 2: بتّ/ثانية. النتيجة: الصيغة العملية. الربط بالذكاء الاصطناعي: تصميم الشبكات.

مثال (28.3-5): مضاعفة القوّة المعطيات: نضاعف S/N من 1 إلى 2. المطلوب: الزيادة. الحل: الخطوة 1: $\log_2 2 = 1$ بتّ إضافي. النتيجة: QAM يزيد بتّات لكلّ رمز. الربط بالذكاء الاصطناعي: تكييف المودَم.

مثال (28.3-6): توسيع النطاق المعطيات: نضاعف B. المطلوب: C. الحل: الخطوة 1: يتضاعف تقريباً (مع ثبات S/N). النتيجة: علاقة خطّية. الربط بالذكاء الاصطناعي: زيادة عرض النطاق.

مثال (28.3-7): القناة الثابتة المعطيات: $p(y \mid x) = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}$. المطلوب: تقدير C. الحل: الخطوة 1: نعظّم I على $p(x)$ عدديّاً. النتيجة: ≈ 0.4 بت (دقيق حسب الحساب). الربط بالذكاء الاصطناعي: قنوات غير متناظرة.

مثال (28.3-8): رمز التكرار المعطيات: نكرّر كلّ بتّ 3 مرّات. المطلوب: الفكرة. الحل: الخطوة 1: تصحيح خطأ واحد (majority vote). الخطوة 2: $R = 1/3$، وكلّما نقصت R تحت C اقترب الخطأ من الصفر. النتيجة: أبعد مثال تصحيح. الربط بالذكاء الاصطناعي: تصحيح أخطاء البيانات.

مثال (28.3-9): معدّل فوق السعة المعطيات: $R = 0.6$، $C = 0.5$. المطلوب: النتيجة. الحل: الخطوة 1: خطأ لا يقترب من الصفر. الخطوة 2: لا يوجد تعمية مثاليّة. النتيجة: استحالة. الربط بالذكاء الاصطناعي: حدّ من نظرية المعلومات.

مثال (28.3-10): تصحيح الأخطاء الحديث المعطيات: LDPC/Polar. المطلوب: الأداء. الحل: الخطوة 1: للقنوات المتناظرة تقترب من C. النتيجة: نجاح شانون. الربط بالذكاء الاصطناعي: التخزين/Li-Fi/5G.

مثال (28.3-11): طبيعة القناة في التدريب المعطيات: النموذج كمرسل/مستقبل. المطلوب: العلاقة. الحل: الخطوة 1: ضغط الميزات $\Rightarrow$ ترميز المعلومات المهمّة فقط. الخطوة 2: Bottleneck يفرض C. النتيجة: تفسير نظرية المعلومات للتعلم. الربط بالذكاء الاصطناعي: information bottleneck.

مثال (28.3-12): ذاكرة القناة المعطيات: قناة بذاكرة. المطلوب: C. الحل: الخطوة 1: لم تعد بسيطة؛ نحسب $I(X^n;Y^n)$. النتيجة: $C = \lim_n \frac{1}{n}\max I$. الربط بالذكاء الاصطناعي: قنوات زمنية.

مثال (28.3-13): قناة الطلب المعطيات: قناة كبيرة الخسارة (BSC). المطلوب: التفسير الحل: الخطوة 1: نستخدم $I = H(Y) - H(Y \mid X)$. الخطوة 2: $H(Y \mid X) = h(p)$ (إنتروبيا ضجيج). النتيجة: صيغة مباشرة. الربط بالذكاء الاصطناعي: أداة حسابية.

مثال (28.3-14): قناة قابلة للمسح المعطيات: نرسل عدة رموز معاً. المطلوب: I الحل: الخطوة 1: نحسب $I(X;Y)$ للمشترك. الخطوة 2: التعظيم يصعب. النتيجة: نحسب I لكلّ الاستخدامات. الربط بالذكاء الاصطناعي: مشفرات MIMO.

مثال (28.3-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: القيمة الحل: الخطوة 1: C مفهوم عميق يربط المعلومات بالفيزياء. النتيجة: أساس اتصالاتنا. الربط بالذكاء الاصطناعي: الضوضاء/التكرار/التصحيح.

أخطاء شائعة

- الخلط بين $I(X;Y)$ و C (الأخير هو الأعظمي).
- استخدام $R = C$ عملياً (قابل للصفر فقط).
- إهمال أن S/N يزيد C لوغاريتمياً.
- نسيان أن القنوات الذاكرة تحتاج C_n ليس C.

خوارزمية بناء شيفرة فوريّة مثلى: ندمج الأقلّ احتمالاً تكراراً ثمّ نأخذ 0 و 1 للفرعين:

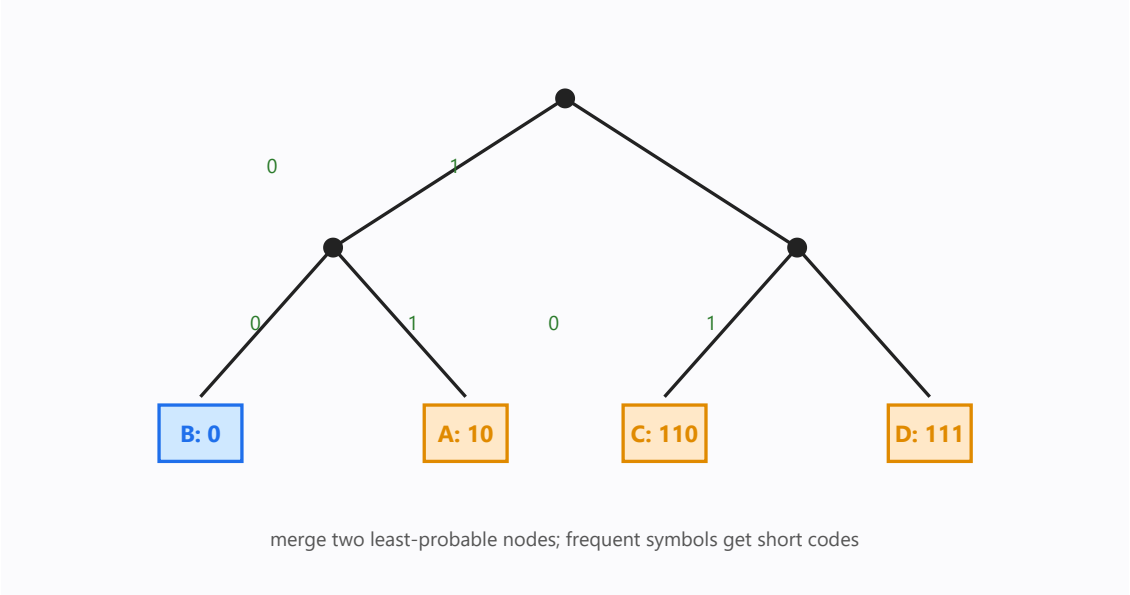
$$\ell_i \approx \log_2 \frac{1}{p_i}, \qquad \min L = \sum p_i \ell_i, \qquad H \le L < H + 1 \tag{3.28}$$

جدول الرموز

الرمز	المعنى
هافمان	خوارزمية دمج متكرّرة
فورية (prefix-free)	لا شيفرة بادئة
L	متوسط الطول
شجرة	بنية ثنائيّة

الرسم

<figure> الشكل<figcaption> 3.28: ندمج أقلّ احتمالين حتى الجذر؛ رموز شائعة تأخذ مساراً أقصر.</figcaption>



شكل ٣.٢٨: *
ترميز هافمان: شجرة الدمج

</figure>

البرهان (مخطّط)

نبدأ بأشجار ثنائيّة. بشكل استقرائي، يجب أن يكون أخوان بأطول شيفرة هما الأقلّ احتمالاً (وإلّا كان تبادلهما يقلّل L). بدمجهما في رمز جديد واحد نفصل المشكلة، وبخطّية L والاستقراء نصل إلى الأمثل. ■

خمسة عشر مثالاً محلولاً

مثال (28.4-1): رمزان متساويان المعطيات: $(0.5, 0.5)$ $\Rightarrow$ p. المطلوب: الشيفرة. الحل: الخطوة 1: رموز 0 و 1. الخطوة 2: $L = 1 = H$. النتيجة: مثالي. الربط بالذكاء الاصطناعي: أبسط Huffman tree.

مثال (28.4-2): أربعة منحازة المعطيات: $(0.5, 0.25, 0.125, 0.125)$. المطلوب: L. الحل: الخطوة 1: ندمج $0.125 + 0.125 = 0.25$. الخطوة 2: نلاحق حتى الجذر، الأطوال $1, 2, 3, 3$. الخطوة 3: $L = 0.5(1) + 0.25(2) + 2(0.125)(3) = 0.5 + 0.5 + 0.75 = 1.75$. النتيجة: $L = 1.75$ قرب $H = 1.75$. الربط بالذكاء الاصطناعي: مثال كتيّبي.

مثال (28.4-3): مقارنة ثابتة المعطيات: نفس المثال بطول 2. المطلوب: التوفير. الحل: الخطوة 1: $L = 2$ مقابل 1.75. الخطوة 2: توفير 12.5%. النتيجة: مكسب واضح. الربط بالذكاء الاصطناعي: ضغط منحرف.

مثال (28.4-4): جدول التحويل المعطيات: رموز A..E باحتمالات معلومة. المطلوب: الشيفرة. الحل: الخطوة 1: نبدأ بأقلّ احتمالين. الخطوة 2: نبني الشجرة ثمّ نقرأ المسارات. النتيجة: جدول شيفرة. الربط بالذكاء الاصطناعي: ممارسة شائعة.

مثال (28.4-5): ثلاث احتمالات المعطيات: $(0.5, 0.3, 0.2)$. المطلوب: L. الحل: الخطوة 1: دمج $0.2+0.3 = 0.5$. الخطوة 2: أطوال $1, 2, 2$. الخطوة 3: $L = 0.5 + 0.6 + 0.4 = 1.5$. النتيجة: 5.1 بت. الربط بالذكاء الاصطناعي: الهالة أقلّ من H+1 دائماً.

مثال (28.4-6): فوريّة المعطيات: شيفرة $0, 10, 11$. المطلوب: هل فوريّة؟ الحل: الخطوة 1: لا شيفرة بادئة لأخرى. النتيجة: نعم. الربط بالذكاء الاصطناعي: فكّ مباشر بلا تخزين.

مثال (28.4-7): ليست فوريّة المعطيات: $0, 01, 10$. المطلوب: مثال. الحل: الخطوة 1: «0010» لها تفسيران. النتيجة: غير قابلة للفكّ ببساطة. الربط بالذكاء الاصطناعي: Huffman يضمن الفوريّة.

مثال (28.4-8): تطبيق على نصوص المعطيات: توزيع الحروف. المطلوب: الضغط. الحل: الخطوة 1: أبجديّة إنجليزية $\Rightarrow$ توفير ~2 بتّ/حرف. النتيجة: تحسين ملموس. الربط بالذكاء الاصطناعي: ZIP/GZIP.

مثال (28.4-9): تعليمات المعالج المعطيات: opcodes غير متكافئة. المطلوب: التطبيق. الحل: الخطوة 1: أطوال متغيّرة للأكثر استخداماً. النتيجة: صغر حجم البرامج. الربط بالذكاء الاصطناعي: أنظمة حاسوبية.

مثال (28.4-10): رموز متغييرة الطول المعطيات: توزيع ظرفي. المطلوب: الأداة. الحل: الخطوة 1: Huffman تكيّفي (dynamic). النتيجة: يعدّل الشجرة. الربط بالذكاء الاصطناعي: ضغط متدفّق.

مثال (28.4-11): الترميز الحسابي المعطيات: نطاقات (انظر 5.28). المطلوب: المقارنة. الحل: الخطوة 1: Huffman لا يقلّل الرموز المفردة. الخطوة 2: الحسابي يقترب من H كسلسلة. النتيجة: أفضل للتوزيعات. الربط بالذكاء الاصطناعي: ضغط فائق.

مثال (28.4-12): العيب الجوهري المعطيات: $p = 2^{-20}$ نادر. المطلوب: الطول؟ الحل: الخطوة 1: عمق الشجرة (حتى 20 بتّ أو أكثر). الخطوة 2: سيعطيه Huffman طوالاً غير واقعي. النتيجة: غير عملي للنوادر. الربط بالذكاء الاصطناعي: مزج بالحسابي.

مثال (28.4-13): بنية الشجرة المعطيات: احصِ القواعد. المطلوب: الترتيب. الحل: الخطوة 1: طابور أوّليّة (priority queue). الخطوة 2: كلّ دمج عقدة جديدة. النتيجة: $O(n \log n)$. الربط بالذكاء الاصطناعي: التقنية البرمجية.

مثال (28.4-14): ترميزات متعدّدة المعطيات: يوجد حلّ Huffman متعدّد. المطلوب: الملاحظة. الحل: الخطوة

1: طول التحسين فريد، أما الشيفرة فقد لا. النتيجة: تباين شائع. الربط بالذكاء الاصطناعي: لا قلق من تباين المعالجات.

مثال (4.28-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: القيمة الحل: الخطوة 1: Huffman يبني الأمثل بين الشيفرات الرمزية. النتيجة: خوارزمية عمليّة شهيرة. الربط بالذكاء الاصطناعي: أساس الضغط الكلاسيكي.

أخطاء شائعة

- نسيان أن Huffman لرمز وحيد يظلّ عرضيّاً.
- بناء شيفرة غير فوريّة (لبس في الفكّ).
- الطمع المحلي دون صفّ بدء صحيح.
- نسيان أن حدوده $H+1$ لكلّ رمز لا للسلسلة.

بدل إسناد شيفرة لكلّ رمز، نخصص للسلسلة كلّها فترة جزئية داخل $[0,1)$:

$$\text{الطول} \approx \log_2 \frac{1}{p(x_1..x_n)} \approx nH \qquad \text{بحجم} \prod_i p(x_i), \qquad [\mathrm{lo}_n, \mathrm{hi}_n) \tag{4.28}$$

جدول الرموز

الرمز	المعنى
lo, hi	حدود الفترة
فترة جزئية	جزء متداخل من $[0,1)$
nH	طول تقريبي للسلسلة
إعادة التحجيم	عند نقص الدقة العددية

الرسم

<figure> الشكل<figcaption> 4.28: كلّ رمز يقسّم الفترة إلى أجزاء متناسبة مع احتمالاته.</figcaption>
</figure>

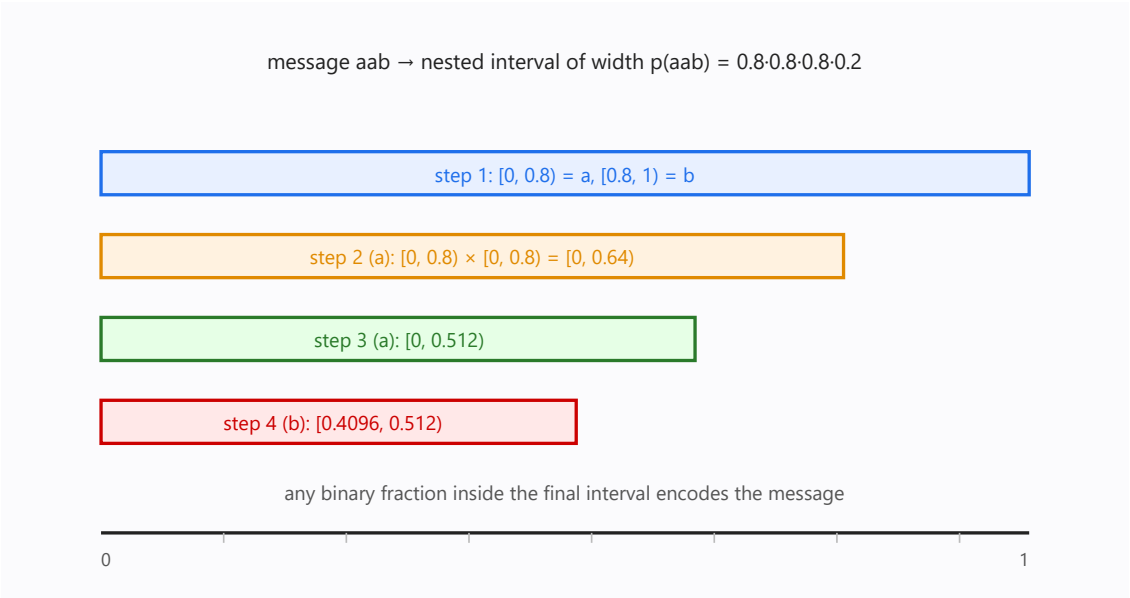
البرهان (مخطّط)

لو رمزنا مصدراً طبيعاً متّسق التوزيع، فإنّ احتمال سلسلة x^n يساوي $\prod p(x_i)$، وبالتالي طول الفترة يساويه؛ وأيّ نقطة داخلها تكفي لتمثيل السلسلة (فكّها يقتضي مقارنة سريعة بالفواصل). ■

خمسة عشر مثالاً محلولاً

مثال (5.28-1): تقسيم أولي المعطيات: a بـ 0.7، b بـ 0.3. المطلوب: الفترات. الحل: الخطوة 1: $a \mapsto [0, 0.7)$، $b \mapsto [0.7, 1)$. النتيجة: فترتان. الربط بالذكاء الاصطناعي: أساس الترميز الحسابي.

مثال (5.28-2): رمزان متتاليان المعطيات: «ab». المطلوب: الفترة. الحل: الخطوة 1: ناخذ فترة a ثمّ نقسمها: $b = [0.49, 0.7)$ بعرض 0.21. النتيجة: عرض $= 0.3 \times 0.7 = 0.21$. الربط بالذكاء الاصطناعي: عرض الفترة يساوي احتمال السلسلة. مثال (5.28-3): الطول المعطيات: فترة بعرض 0.21. المطلوب: البتّات. الحل: الخطوة 1: $-\log_2 0.21 \approx 2.25$ بت. النتيجة: ≈ 25.2 بت. الربط بالذكاء الاصطناعي: قريب من مجموع سجلّات الاحتمالات.



شكل ٤٠٢٨: *
الترميز الحسابي: فترات متداخلة

مثال (28-5-4): ثلاثة رموز المعطيات: $(0.5, 0.25, 0.25)$، سلسلة «aab». المطلوب: العرض. الحل: الخطوة 1: $0.5 \times 0.5 \times 0.25 = 0.0625$. الخطوة 2: الطول $L = 4$ بتّات. النتيجة: 4 بتّات. الربط بالذكاء الاصطناعي: يمكن تخصيص نقطة داخل الفترة في 4 بتّات.

مثال (28-5-5): الفكّ المعطيات: نقطة داخل فترة معقّدة. المطلوب: كيف نسترجع السلسلة؟ الحل: الخطوة 1: نتحقّق في أيّ فترة رمز وقعت. الخطوة 2: نكرّر حتى استنفاد البايتات. النتيجة: فكّ تكراري. الربط بالذكاء الاصطناعي: خوارزمية فكّ قياسية.

مثال (28-5-6): مقارنة بهافمان المعطيات: توزيع ذي ترددات. المطلوب: الفرق. الحل: الخطوة 1: الحسابي يرمّز السلسلة كتلةً واحدة. الخطوة 2: لا «بتّات مهدورة» بسبب تكديس الأطوال. النتيجة: يلامس H بدقّة أعلى. الربط بالذكاء الاصطناعي: الضغط المتقدّم.

مثال (28-5-7): مثال عددي بسيط المعطيات: سلسلة «ba». المطلوب: الفترة. الحل: الخطوة 1: $b \mapsto [0.7, 1)$؛ ثمّ قسمة: $a = [0.7, 0.91)$. الخطوة 2: العرض $0.21 =$. النتيجة: الفترة والدقّة. الربط بالذكاء الاصطناعي: تمرين متكرّر.

مثال (28-5-8): العدد العشري المنتهي المعطيات: نريد تمثيلاً قصيراً. المطلوب: نقطة داخلية. الحل: الخطوة 1: نأخذ $(\text{lo} + \text{hi})/2$ بتقريب محدد. الخطوة 2: نطبع عدداً عشريّاً كافياً. النتيجة: إخراج مضغوط. الربط بالذكاء الاصطناعي: تفاصيل سريّة الملفّ.

مثال (28-5-9): دقّة النقطة العائمة المعطيات: فترة صغيرة جدّاً. المطلوب: الخطر. الحل: الخطوة 1: الفقد يفسد الفكّ. الخطوة 2: نعيد التحجيم (E1/E2/E3 scaling). النتيجة: التنفيذ العملي. الربط بالذكاء الاصطناعي: تفاصيل تنفيذ.

مثال (28-5-10): توزيعات سياقية المعطيات: نغيّر الاحتمال بالسياق. المطلوب: التحسّن. الحل: الخطوة 1: نماذج تكيّفية ترفع نسبة الضغط. النتيجة: PPM/LZMA. الربط بالذكاء الاصطناعي: نهاية نظرية الترميز.

مثال (28-5-11): الصور المعطيات: تحويل بترددات. المطلوب: الأداة. الحل: الخطوة 1: حوّل لمعاملات نادرة ثمّ الحسابي. النتيجة: JPEG/WebP. الربط بالذكاء الاصطناعي: تطبيقات الوسائط.

مثال (28.5-12): النصوص الطويلة المعطيات: نصوص ضخمة. المطلوب: الأداء. الحل: الخطوة 1: يقترب من H كسلسلة. الخطوة 2: ليس عرضيّاً كهافمان. النتيجة: ضغط أقوى. الربط بالذكاء الاصطناعي: تخزين واسع.

مثال (28.5-13): الرموز عند الأطراف المعطيات: فترة تقع قرب 1. المطلوب: التطبيع. الحل: الخطوة 1: نستخدم underflow handling. النتيجة: ثبات. الربط بالذكاء الاصطناعي: هندسة التنفيذ.

مثال (28.5-14): مقارنة بالحساب المعطيات: Huffman مقابل Arithmetic. المطلوب: الجدول. الحل: الخطوة 1: لعرض: Arithmetic أفضل للتوزيع المنحرف. الخطوة 2: لسرعة: Huffman أسرع. النتيجة: مقايضة. الربط بالذكاء الاصطناعي: اختيار الخوارزمية.

مثال (28.5-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: القيمة الحل: الخطوة 1: الترميز الحسابي يقترب من حدّ شانون للسلسلة. النتيجة: تقنية حديثة قويّة. الربط بالذكاء الاصطناعي: عمود فقري للضغط.

أخطاء شائعة

- إغفال إعادة التحجيم فتحدث أخطاء عائمة.
- محاولة فكّ قبل تدقيق الفواصل.
- الخلط بين فترات الرمز وفترات السلسلة.
- نسيان أن الفكّ يحتاج نموذج الاحتمالات نفسه.

لكلّ ترميز فوري بطول $\{\ell_i\}$ على أبجديّة بحجم D:

$$\sum_i D^{-\ell_i} \;\le\; 1 \tag{28.5}$$

والعكس صحيح: لأيّ مجموعة أطوال تحقّقها يوجد ترميز فوري مقابل.

جدول الرموز

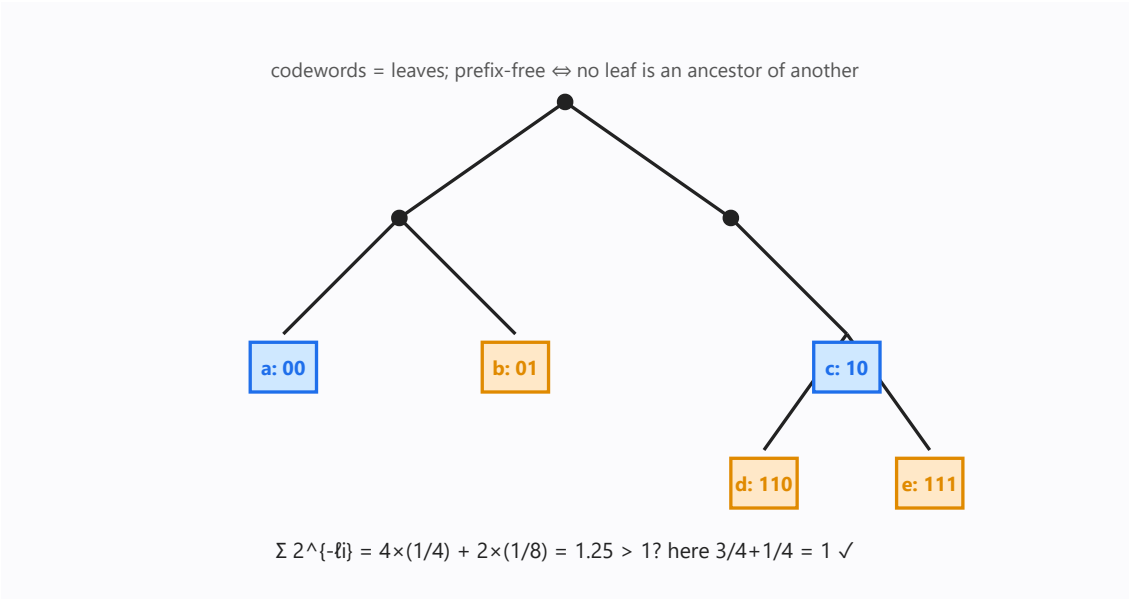
الرمز	المعنى
D	حجم الأبجديّة (2 للبتّ)
ℓ_i	طول شيفرة الرمز i
فوري	prefix-free
مكمّل	تحقيق المساواة

الرسم

<figure> الشكل<figcaption> 28.5: كلّ شيفرة «تحتلّ» عدداً من الأوراق في شجرة ثنائية؛ المجموع لا يتجاوز الوحدة.</figcaption> </figure>

البرهان (مخطّط)

نبني شجرة كاملة حيث لكلّ رمز ورقة على مستوى ℓ_i. الشيفرة الفوريّة تعني عدم احتواء أيّ ورقة على أخرى، والمجموع $\sum D^{-\ell_i}$ هو عدد الأوراق الموزّعة $\Rightarrow$ لا يتجاوز 1. ■



شكل ٥.٢٨: *
مترابحة كرافت: شجرة البتّات

خمسة عشر مثالاً محلولاً

مثال (1-6.28): متساوية الطول المعطيات: 8 رموز بـ 3 $\ell = 3$ لأبجديّة 2. المطلوب: كرافت. الحل: الخطوة 1: $8 \times 2^{-3} = 1$. النتيجة: مساواة (شجرة مليئة). الربط بالذكاء الاصطناعي: الترميز الثابت مثال قياسي.

مثال (2-6.28): هافمان المذكور المعطيات: أطوال $1, 2, 3, 3$. المطلوب: المجموع. الحل: الخطوة 1: $\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{8} = 1$. النتيجة: مساواة. الربط بالذكاء الاصطناعي: شيفرة هافمان تكمل الشجرة.

مثال (3-6.28): أطوال مستحيلة المعطيات: $(1, 1, 1)$ $\ell = 1$. المطلوب: كرافت؟ الحل: الخطوة 1: $3 \times \frac{1}{2} = 1.5 > 1$. النتيجة: لا يوجد ترميز فوري. الربط بالذكاء الاصطناعي: كشف جدوى مجموعة أطوال.

مثال (4-6.28): أبجديّة كبيرة المعطيات: $D = 4$، $\ell = (1, 2)$. المطلوب: المجموع. الحل: الخطوة 1: $\frac{1}{4} + \frac{1}{16} = 0.3125 \le 1$. النتيجة: ممكن. الربط بالذكاء الاصطناعي: تعميم على D.

مثال (5-6.28): الإثبات من الطول المتوقّع المعطيات: نريد $H \le L$. المطلوب: الاستخدام. الحل: الخطوة 1: نطبّع $\sum 2^{-\ell} \le 1$. الخطوة 2: بجنسن على $-t \log t$ نحصل على $H \le L$. النتيجة: برهان بلا تكاملات. الربط بالذكاء الاصطناعي: جمال المبرهنة.

مثال (6-6.28): المساواة فقط للنظافة المعطيات: شجرة غير مليئة. المطلوب: النتيجة. الحل: الخطوة 1: المجموع $< 1 \Rightarrow$ شيفرة غير مثلى. النتيجة: يمكن تقصير رمز. الربط بالذكاء الاصطناعي: إشارة لتحسين.

مثال (7-6.28): اختبار ثلاثي المعطيات: $\ell = (1, 2, 2, 3)$. المطلوب: كرافت؟ الحل: الخطوة 1: $0.5 + 0.25 + 0.125 = 1.125 > 1$. النتيجة: غير ممكن. الربط بالذكاء الاصطناعي: تدريب سريع.

مثال (8-6.28): وجود مقابل المعطيات: $\ell = (1, 2, 3, 3)$ يتحقّق. المطلوب: دليل العكس. الحل: الخطوة 1: نبني شجرة والورقتين الباقيتين. النتيجة: يوجد ترميز. الربط بالذكاء الاصطناعي: نظرية كاملة.

مثال (9-6.28): رموز وحدات المعطيات: $D = 2$، $\ell = (2, 2, 2, 2)$. المطلوب: المجموع. الحل: الخطوة 1: $4/4 = 1$. النتيجة: مستوفاة. الربط بالذكاء الاصطناعي: 4 رموز بـ 2 بتّ.

مثال (10-6.28): كرافت للثلاثي المعطيات: $D = 3$، $\ell = (1, 1, 2)$. المطلوب: المجموع. الحل: الخطوة 1: $\frac{1}{3} + \frac{1}{3} + \frac{1}{9} = 0.778 \le 1$. النتيجة: ممكن لكن غير أمثل. الربط بالذكاء الاصطناعي: شجرة ثلاثية.

مثال (11-6.28): رموز منتهية المعطيات: $\ell = (1, 2, 2)$. المطلوب: المجموع. الحل: الخطوة 1: $\frac{1}{2} + \frac{1}{4} + \frac{1}{4} = 1$.

النتيجة: تكامل تامّ. الربط بالذكاء الاصطناعي: مثال شائع.

مثال (6.28-12): لماذا $D^{-\ell}$ المعطيات: الإجابة البنيوية. المطلوب: المعنى. الحل: الخطوة 1: $D^{-\ell}$ = نسبة العقد/الأوراق المحجوزة. النتيجة: حساب مساحة الشجرة. الربط بالذكاء الاصطناعي: حدس هندسي.

مثال (6.28-13): الترميز غير الفوري المعطيات: لا يخضع كرافت. المطلوب: البديل. الحل: الخطوة 1: McMillan يعمّم لغيرالفوري. النتيجة: المتراجحة تبقى. الربط بالذكاء الاصطناعي: تعميم مهمّ.

مثال (6.28-14): تطبيق على الموديل المعطيات: نريد توزيع احتمالات. المطلوب: التطابق. الحل: الخطوة 1: أطوال q_i تحقّق كرافت $\Rightarrow$ توزيع. الخطوة 2: $\sum 2^{-q_i} \leq 1$. النتيجة: ربط عميق. الربط بالذكاء الاصطناعي: تفسير احتمالي للأطوال.

مثال (6.28-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: القيمة الحل: الخطوة 1: كرافت معيار جدوى سريع قبل بناء أيّ ترميز. النتيجة: أداة فحص عمليّة. الربط بالذكاء الاصطناعي: خطوة أولى في تصميم الخوارزميات.

أخطاء شائعة

- نسيان أن كرافت للترميز «الفوري» تحديداً.
- استخدام D^{-1} غير الصحيح للأبجديّة.
- اعتبار المجموع < 1 دليلاً دائماً على الأمثل.
- خلط بين كرافت وشروط Huffman (لها علاقة لكن ليست واحدة).

نبحث عن أقلّ معدّل R يحقّق تشويهاً متوسطاً $\leq D$:

$$R(D) = \min_{p(\hat{x}|x):\ \mathbb{E}d(X,\hat{X}) \leq D} I(X;\hat{X}) \tag{6.28}$$

ولغاوسي بتباين σ^2 وخطأ تربيعي: $R(D) = \frac{1}{2}\log_2 \frac{\sigma^2}{D}$ عند $D < \sigma^2$، و $R = 0$ لـ $D \geq \sigma^2$.

جدول الرموز

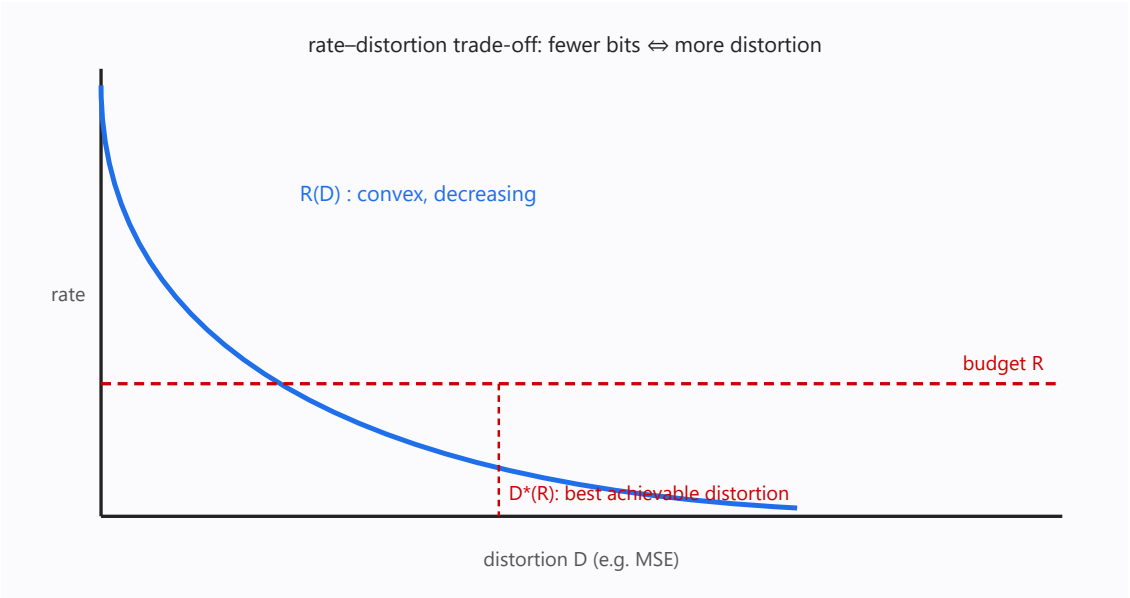
الرمز	المعنى
$\hat{X}$	إعادة الإعمار
$d(\cdot,\cdot)$	دالّة تشويه
D	حدّ التشويه
$R(D)$	دالّة معدّل–تشويه

الرسم

<figure> الشكل<figcaption> 6.28: كلّ تشويه أقصى يفرض معدّلاً أدنى؛ المنحنى يتحدّب تنازلياً.</figcaption>
</figure>

البرهان (مخطّط)

البحث هو تعظيم $I(X;\hat{X})$ على كلّ القنوات الرابطة التي تحترم قيد التشويه؛ بما أنّ I محدّبة في $p(\hat{x} \mid x)$ و D خطّي فيه، تكون المسألة محدّبة ويوجد حلّ مميّز؛ لغاوسي يوافق Lagrange إلى النموذج الغاوسي العكسي. ■



شكل ٦.٢٨: *
معدل-تشويه: التخلي عن الدقة مقابل البتات

خمسة عشر مثالاً محلولاً

مثال (1-7.28): التمثيل المعطيات: مصدر بإنتروبيا H. المطلوب: لماذا $R(D)$؟ الحل: الخطوة 1: عند $D = 0$ نستعيد المصدر $\Rightarrow R = H$. النتيجة: نقطة بديلة. الربط بالذكاء الاصطناعي: الضغط بلا خسارة.

مثال (2-7.28): تشويه مطلق المعطيات: D كبير جدّاً. المطلوب: $R(D)$. الحل: الخطوة 1: $R = 0$ (نتخلّى عن المصدر). النتيجة: لا حاجة لأيّ بتّات. الربط بالذكاء الاصطناعي: طيّ مستويات الجودة.

مثال (3-7.28): غاوسي المعطيات: $\sigma^2 = 4$، $D = 1$. المطلوب: $R(D)$. الحل: الخطوة 1: $\frac{1}{2}\log_2 \frac{4}{1} = 1$ بت. النتيجة: 1 بت/عيّنة. الربط بالذكاء الاصطناعي: ضغط صوت/صورة.

مثال (4-7.28): D صغيرة المعطيات: $D = 0.5$. المطلوب: $R(D)$. الحل: الخطوة 1: $\frac{1}{2}\log_2 8 = 1.5$ بت. الخطوة 2: زادت الدقّة $\Rightarrow$ معدّل أعلى. النتيجة: 1.5 بت. الربط بالذكاء الاصطناعي: التخلي عن البتّات شبه غير خطّي.

مثال (5-7.28): $D = \sigma^2$ المعطيات: $\sigma^2 = D = 4$. المطلوب: R. الحل: الخطوة 1: $\frac{1}{2}\log_2 1 = 0$. النتيجة: صفر. الربط بالذكاء الاصطناعي: إعادة الإعمار الثابت.

مثال (6-7.28): مقارنة الضغط المعطيات: نريد جودة 90٪. المطلوب: القرار. الحل: الخطوة 1: نختار D بما يوافق نسبة SNR. الخطوة 2: $R(D)$ يعطي الحدّ الأدنى. النتيجة: هدف واقعي. النتيجة: مثال مثل JPEG/WebP.

مثال (7-7.28): التقطير المعطيات: نموذج كبير يصغّر. المطلوب: الرابط. الحل: الخطوة 1: نقل المعرفة = تلخيص بلا خسارة كبيرة. الخطوة 2: $R(D)$ يحدّد مقياساً نظريّاً للفقد. النتيجة: ترجمة عمليّة. الربط بالذكاء الاصطناعي: model compression.

مثال (8-7.28): quantizer المعطيات: نمطّم الكثافة. المطلوب: الدور. الحل: الخطوة 1: التمثيل يعطي $\hat{X}$، R عدد المستويات. الخطوة 2: D خطأ التكمية. النتيجة: مقايضة مباشرة. الربط بالذكاء الاصطناعي: مضغوطة NN (INT8).

مثال (9-7.28): التحسينات المتّصلة المعطيات: $R(D)$ نازل محدّب. المطلوب: التفسير. الحل: الخطوة 1: كلّ بتّ إضافي يخفّف التشويه بكمّية متناقصة. الخطوة 2: الحدّ الأقصى قبل $R = 0$. النتيجة: منحنى كلاسيكي. الربط بالذكاء الاصطناعي: تصميم ميزانية البتّات.

مثال (10-7.28): 16-bit إلى 8-bit المعطيات: مصدر مائي المستوى. المطلوب: الفقد. الحل: الخطوة 1: نحسب D الجديد. الخطوة 2: R توفّر 50% تقريباً. النتيجة: كفاءة. الربط بالذكاء الاصطناعي: الاستدلال السريع.

مثال (28.7-11): فقد معدوم المعطيات: نريد صفر فقد. المطلوب: السعر. الحل: الخطوة 1: $H = R$ كامل. الخطوة 2: غالباً مستحيل عملياً. النتيجة: ضغط بلا خسارة مقيّد. الربط بالذكاء الاصطناعي: معيار أداء.

مثال (28.7-12): فيديو المعطيات: 60 إطاراً/ث. المطلوب: القرار. الحل: الخطوة 1: $R(D)$ الإجمالي = المجموع. الخطوة 2: توزيع D بحسب الحركة. النتيجة: ضغط فيديو. الربط بالذكاء الاصطناعي: H.264/H.265.

مثال (28.7-13): تنقيط الشبكة العصبية المعطيات: أحجام WEIGHTS. المطلوب: المكافئ. الحل: الخطوة 1: تكمية للأوزان والمُنشّطات. الخطوة 2: $R(D)$ يوجّه اختيار البتّات. النتيجة: التقدير على الأجهزة. الربط بالذكاء الاصطناعي: AI edge.

مثال (28.7-14): الحدّ العلوي لـ D المعطيات: $D \geq \sigma^2$. المطلوب: التحقق. الحل: الخطوة 1: بإخراج ثابت c يكون $R = 0 \Rightarrow \mathbb{E}(X-c)^2 = \sigma^2$. النتيجة: منطقي. الربط بالذكاء الاصطناعي: نقطة توقّف مفيدة.

مثال (28.7-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: القيمة الحل: الخطوة 1: $R(D)$ يحدّد الدقّة التي نستحقّها لكلّ بتّ. النتيجة: إطار نظري مركزي. الربط بالذكاء الاصطناعي: هندسة تمثيل البيانات.

أخطاء شائعة

- الخلط بين $R(D)$ و H (الأول تحت تشويه).
- استخدام D نسبياً بلا مقياس واضح.
- نسيان أن $R(D) = 0$ فوق σ^2.
- إغفال أن $\hat{X}$ متغيّر عشوائي لا قيمة ثابتة.

MDL يختار النموذج الذي يقصر وصف البيانات **بعد** وصف النموذج نفسه:

$$\mathcal{L}_{\text{total}}(m, D) = \underbrace{\ell(m)}_{\text{وصف النموذج}} + \underbrace{\ell(D \mid m)}_{\text{وصف البيانات بالنموذج}}, \qquad m^\star = \arg\min_m \mathcal{L}_{\text{total}} \tag{7.28}$$

جدول الرموز

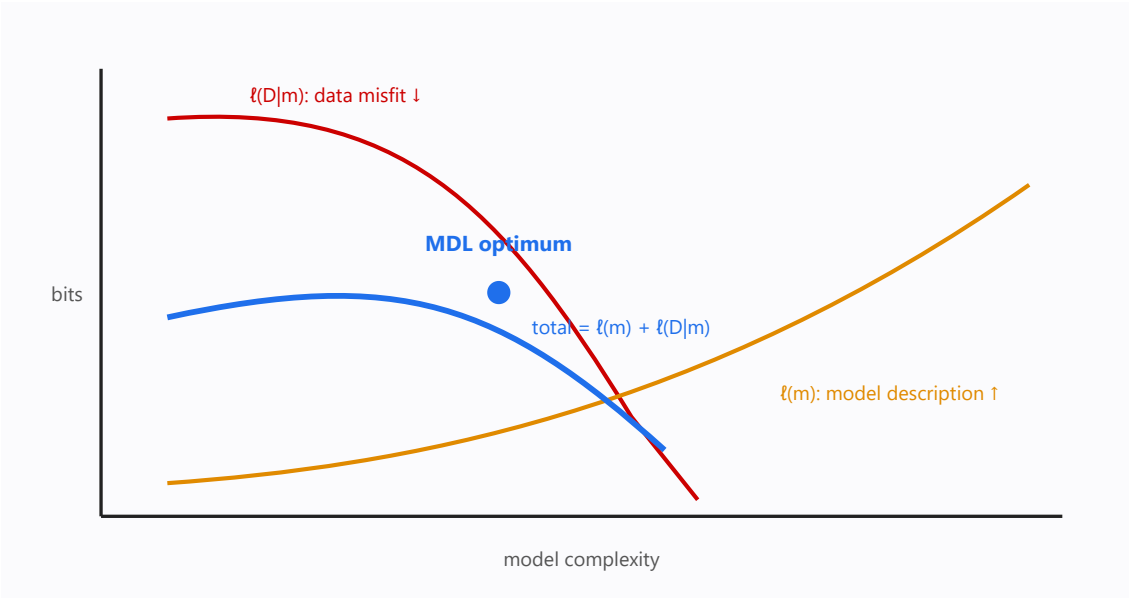
الرمز	المعنى
$\ell(m)$	بتّات وصف النموذج
$\ell(D \mid m)$	بتّات وصف البيانات مع النموذج
MDL	Length Description Minimum
overfitting	وصف بيانات بلا وصف نموذج

الرسم

<figure> الشكل<figcaption> 7.28: نموذج معقّد يصف البيانات بأناقة لكن يطيل وصف نفسه؛ MDL يوازن الطرفين.</figcaption> </figure>

البرهان (مخطّط)

من مبرهنة الترميز المصدري (28.1): $\ell(D \mid m) \approx -\log p(D \mid m)$، و $\ell(m) \approx -\log p(m)$. المجموع هو $-\log p(m, D)$؛ فاختيار MDL يكافئ اختيار أقصى احتمال مشترك للنموذج والبيانات (بايز). ■



شكل ٧.٢٨: *
مبدأ الوصف الأقصر: وصف النموذج زائد وصف البيانات

خمسة عشر مثالاً محلولاً

مثال (28.8-1): الصياغة المعطيات: نموذجان لمجموعة بيانات. المطلوب: الأفضل. الحل: الخطوة 1: نحسب $L_1 = \ell_1 + \ell(D \mid 1)$ و L_2 مماثلاً. الخطوة 2: نختار الأصغر. النتيجة: مقارنة عادلة. الربط بالذكاء الاصطناعي: ترشيح النماذج.

مثال (28.8-2): نموذج بسيط المعطيات: انحياز ثابت فقط. المطلوب: L. الحل: الخطوة 1: $\ell(m)$ صغير، $\ell(D \mid m)$ كبير. النتيجة: عجز عن التفسير .(underfitting) الربط بالذكاء الاصطناعي: كشف نقص التعقيد.

مثال (28.8-3): نموذج مفرط المعطيات: يمرّ بكلّ نقطة. المطلوب: L. الحل: الخطوة 1: $\ell(m)$ ضخم، $\ell(D \mid m)$ صغير. النتيجة: .overfitting الربط بالذكاء الاصطناعي: كشف الإفراط.

مثال (28.8-4): التوازن المعطيات: نموذج وسيط. المطلوب: الحكم. الحل: الخطوة 1: يقلّل المجموع. النتيجة: نموذج MDL الأمثل. الربط بالذكاء الاصطناعي: اختيار تلقائي.

مثال (28.8-5): ربط بـ AIC المعطيات: AIC يعاقب بعدد المعاملات. المطلوب: الشبه. الحل: الخطوة 1: AIC $\approx -2\ln L + 2k$، MDL $\approx \ln L + \ln k$. الخطوة 2: كلاهما يمنع الوصف المفرط. النتيجة: عائلة واحدة. الربط بالذكاء الاصطناعي: اختيار النموذج (18).

مثال (28.8-6): ربط بـ Occam المعطيات: قاعدة الموس. المطلوب: العلاقة. الحل: الخطوة 1: MDL تعطي صياغة حسابيّة لـ «الأبسط». النتيجة: تبرير كمّي. الربط بالذكاء الاصطناعي: فلسفة النمذجة.

مثال (28.8-7): ربط بـ بايز المعطيات: $p(m) \propto 2^{-\ell(m)}$. المطلوب: التطابق. الحل: الخطوة 1: MAP = MDL بسابق طولي. النتيجة: تفسير بايزي. الربط بالذكاء الاصطناعي: توحيد.

مثال (28.8-8): مثال سلسلة المعطيات: 0000000000. المطلوب: النموذج الأقصر. الحل: الخطوة 1: «نموذج: كلّها أصفار» ≈ بضعة بتّات. الخطوة 2: وصف ساذج: 10 بتّات. النتيجة: MDL يفوز. الربط بالذكاء الاصطناعي: اكتشاف النمط.

مثال (28.8-9): سلسلة عشوائية المعطيات: 0110100101. المطلوب: القرار. الحل: الخطوة 1: لا نموذج مختصر $\Rightarrow \ell(D \mid m) \approx n$. الخطوة 2: نمط مفرط لا يفيد. النتيجة: لا ضغط سبيل. الربط بالذكاء الاصطناعي: كشف العشوائية.

مثال (28.8-10): أشجار القرار المعطيات: تعميق الشجرة. المطلوب: معيار التوقّف. الحل: الخطوة 1: بتّات الشجرة

+ بتّات الأخطاء. الخطوة 2: نتوقّف حين لا تنزل المجموعة. النتيجة: تقليم تلقائي. الربط بالذكاء الاصطناعي: MDL pruning.

مثال (28.8-11): ضغط النموذج المعطيات: شبكة ضخمة. المطلوب: الاستخدام. الحل: الخطوة 1: تكمية/تقشير يقلّل $\ell(\text{weights})$. الخطوة 2: نضبط حتى لا يزيد $\ell(D \mid m)$. النتيجة: نموذج أصغر بلا فقد ملموس. الربط بالذكاء الاصطناعي: model compression.

مثال (28.8-12): اختيار الميزات المعطيات: 1000 ميزة. المطلوب: MDL. الحل: الخطوة 1: كلّ ميزة مختارة تكلّف بتّات وصف. النتيجة: اختيار ضيق. الربط بالذكاء الاصطناعي: feature selection.

مثال (28.8-13): تجميع (clustering) المعطيات: نريد عدد المجموعات. المطلوب: المعيار. الحل: الخطوة 1: K Centroids $\Rightarrow \ell(K, \mu)$ + $\ell(\text{assignments})$. النتيجة: K أمثل. الربط بالذكاء الاصطناعي: clusters اختيار تلقائي.

مثال (28.8-14): أوزان MDL المعطيات: وزن وحدة يمكن كبشه. المطلوب: الملاحظة. الحل: الخطوة 1: ℓ يعتمد على وحدات القياس. الخطوة 2: نحتاج ترميزاً ثابتاً. النتيجة: حذر في التصميم. الربط بالذكاء الاصطناعي: معايرة MDL.

مثال (28.8-15): خلاصة المعطيات: كلّ ما سبق. المطلوب: القيمة الحل: الخطوة 1: MDL يربط الضغط بالاختيار النموذجي. الخطوة 2: مبدأ حسّي ورياضي معاً. النتيجة: أساس نظري للتعميم. الربط بالذكاء الاصطناعي: معيار تصميم.

أخطاء شائعة

- مقارنة نماذج بقياسات مختلفة (bits vs nats).
- نسيان وصف النموذج نفسه.
- تفسير MDL كقاعدة مؤكّدة (هو مبدأ له بدائل).
- استخدام MDL في غير النماذج الاحتمالية.

ملخّص النظريات

النظرية	المفهوم	الأهمّية
28.2 المصدري	$L \geq H$	حدّ الضغط
28.3 السعة	$C = \max I(X;Y)$	حدّ الاتصال
28.4 Huffman	دمج الأقلّ احتمالاً	ترميز عمليّ
28.5 الحسابي	فترة لكلّ سلسلة	يقترب من H
28.6 كرافت	$\sum D^{-\ell} \leq 1$	شرط جدوى
28.7 معدّل-تشويه	$R(D) = \min I(X;\hat{X})$	الدقّة مقابل البتّات
28.8 MDL	$\ell(m) + \ell(D \mid m)$	اختيار نموذج

عشرون تمريناً (مع إجابات مختصرة)

١. صيغة حدّ شانون للمصدر؟ $(L \geq H)$

٢. أكبر من H بأيّ حدّ للرمز؟ $(H + 1)$

٣. ما حجم المجموعة النموذجية؟ $(\approx 2^{nH})$

٤. صيغة السعة؟ $(\max_{p(x)} I(X;Y))$

٥. سعة BSC بـ $p = 0.1$؟ $(1 + h_2(0.1) \approx 0.531)$

٦. سعة BSC بـ $p = 0.5$؟ (0)

٧. صيغة ش‌annon–هارتلي؟ $(B \log_2(1 + S/N))$

٨. هل $R = C$ ممكن؟ (عمليّاً لا، $R < C$ فقط)

٩. كيف يبني Huffman؟ (يدمج الأقلّ احتمالاً تكراراً)

١٠. لماذا هافمان فوريّ؟ (بناء على شجرة ثنائية)

١١. ما يضمنه الترميز الحسابي؟ (يقترب من H سلسلة)

١٢. صيغة كرافت؟ $(\sum D^{-\ell_i} \le 1)$

١٣. المجموع لأطوال $(1, 2, 3, 3)$؟ (1)

١٤. صيغة $R(D)$؟ $(\min_{p(\hat{x}|x)} I(X; \hat{X}))$

١٥. $R(D)$ لغاوسي؟ $(\frac{1}{2} \log_2 \frac{\sigma^2}{D})$

١٦. متى $R = 0$ في الغاوسي؟ $(D \ge \sigma^2)$

١٧. صيغة MDL؟ $(\ell(m) + \ell(D \mid m))$

١٨. لماذا MDL يقاوم الإفراط؟ (يحمّل وصف النموذج تكلفة)

١٩. ربط MDL بـ AIC؟ (كلاهما يعاقب التعقيد)

٢٠. مثال MDL على سلسلة أصفار؟ («كلّها أصفار» أقصر)

فهرس الرموز

الرمز	المعنى
L	طول الترميز المتوقّع
C, R	السعة ومعدّل النقل
ℓ_i	طول شيفرة رمز
$D, R(D)$	التشويه ودالّة المعدّل
$\ell(m)$	وصف النموذج (MDL)

مراجع

- Thomas & Cover — *Elements of Information Theory* (الجزء الثاني).
- MacKay — *Information, Theory, and Learning Algorithms* (المقدّمة و MDL).
- Kobayashi & Han — *Information and Coding Theory for Mathematics*.
- Grünwald — *The Minimum Description Length Principle*.
- Witten, Neal & Cleary — «Arithmetic Coding for Data Compression» (1987).

- Zatorsky & Vereshchagin Kabatiansky, — *Coding Arithmetical on Treatise A*.

خاتمة الجزء الخامس: الفصل 29 يختمه بـ **الهندسة المعلوماتية والقياس فيشر**، حيث يصير فضاء التوزيعات ذا هندسة خاصة يُبنى عليها التدرّج الطبيعي.

الهندسة المعلوماتية وقياس فيشر

«التوزيعات ليست نقاطاً في صندوق؛ إنّها سطحٌ له انحناء، وأقصر طريق بين توزيعين ليس خطّاً مستقيماً.»

الفصلان 26 و27 أعطيانا **كمّاً** للمعلومة (إنتروبيا، تباعد)، والفصل 28 أعطاها **حدّاً فيزيائيّاً** (بتّات وقنوات). هذا الفصل يعطيها **شكلاً هندسيّاً**: عائلة التوزيعات p_θ متشعّبٌ تفاضليّ، وتباعد KL — الذي رأيناه في الفصل 27 — ليس مقياساً للمسافة إلا **موضعيّاً**، حيث يتحوّل إلى مربع طولٍ يقيسه **متر معلومات فيشر**. من هذا المتر تتفرّع ثمرات مباشرة في التعلّم العميق: التدرّج الطبيعي، منطقة الثقة، K-FAC، التنظيم المستمر (EWC)، وخوارزمية EM بوصفها إسقاطات متعامدة.

سبع نظريات:

- **2.29 فضاء التوزيعات متشعّب ريماني ومتر فيشر–راو** — تعريف المتر وانتظامه.
- **3.29 التكافؤ المحلّي: KL = نصف مربع طول فيشر** — والتكافؤان المشهوران لصيغة فيشر.
- **4.29 متراجحة كرامير–راو** — فيشر بوصفه حدّاً لدقّة أيّ مقدّر.
- **5.29 التدرّج الطبيعي** — أشدّ انحدارٍ في متر المعلومة.
- **6.29 البنية المزدوجة: إحداثيات e/m والاتصالات** α — الاستواء المزدوج وتباعد بريغمان.
- **7.29 مسافة فيشر–راو والجيوديسيات** — متر حقيقي على فضاء التوزيعات.
- **8.29 الإسقاطات المعلوماتية: EM والتعلّم العميق** — من EM إلى K-FAC و EWC.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

لنثبت الرموز قبل البدء؛ كلّ ما يلي مبنيّ عليها:

الرمز	المعنى	ملاحظة
$\Theta \subseteq \mathbb{R}^d$	فضاء المعلمات	مفتوح، متصل
$p_\theta(x)$	كثافة/كتلة احتمال	بالنسبة لقياس μ
$\ell(\theta; x) = \log p_\theta(x)$	اللوغاريتم الاحتمالي (log-likelihood)	
∂_i	المشتقّة الجزئية بالنسبة لـ θ^i	$\partial_i = \partial/\partial\theta^i$
$s_\theta(x) = \nabla_\theta \ell(\theta; x)$	دالّة الدرجة (score)	$\mathbb{E}[s_\theta] = 0$
$I(\theta)$ و $g_{ij}(\theta)$	متر فيشر–راو (معلومة فيشر)	نفس الشيء
ds^2	عنصر الطول اللامتناهي الصغر	$ds^2 = d\theta^\top I(\theta) d\theta$
D_{KL}	تباعد كولباك–لايبلر (من 27)	ليس متراً
d_F	مسافة فيشر–راو (متر حقيقي)	موضوع 7.29
η, μ	إحداثيات طبيعية (e) وتوقّعية (m)	6.29
ψ, φ	كمون لوغاريتم القاسم وكمونه المزدوج	Legendre
$\Gamma^{(\alpha)}$	معاملات الاتصال α	6.29
$\tilde{\nabla}$	التدرّج الطبيعي	$I^{-1}\nabla$

الاتفاقيات: نستخدم اللوغاريتم الطبيعي (nats) في كلّ حسابات فيشر، ونذكر البتّات عند المقارنة بالفصول السابقة. كلّ التوزيعات تُفترض **منتظمة** (regular): دعامة p_θ لا تعتمد على θ، والمشتقّتان الأولى والثانية موجودتان، وتبادل المشتقّة مع التكامل مسموح. حالة انتهاك هذه الشروط هي موضوع المثال (10-2.29).

التعريف–المبرهنة: لتكن $\mathcal{M} = \{p_\theta : \theta \in \Theta\}$ عائلةً منتظمةً من التوزيعات. فإنّ

$$g_{ij}(\theta) \;=\; I_{ij}(\theta) \;=\; \mathbb{E}_{p_\theta}\!\left[\partial_i \ell(\theta;X)\,\partial_j \ell(\theta;X)\right] \;=\; \int_{\mathcal{X}} \frac{\partial_i p_\theta(x)\,\partial_j p_\theta(x)}{p_\theta(x)}\,d\mu(x) \tag{1.29}$$

تعرّف **متراً ريمانياً** (موجباً محدّداً عند التعرّف على المعلمة) على $\mathcal{M}$، وعنصر الطول

$$ds^2 \;=\; \sum_{i,j} g_{ij}(\theta)\,d\theta^i d\theta^j \;=\; d\theta^{\top} I(\theta)\,d\theta \tag{2.29}$$

يُسمّى **متر فيشر–راو**. طول منحنى $\gamma:[0,1]\to\mathcal{M}$ هو $L(\gamma)=\int_0^1 \sqrt{\dot\gamma(t)^{\top} I(\gamma(t))\,\dot\gamma(t)}\,dt$.

جدول الرموز

الرمز	المعنى	ملاحظة
g_{ij}	مكوّنات المتر المعلوماتي	مصفوفة $d\times d$ متماثلة
$\partial_i \ell$	مكوّنة الدرجة (score) i	متوسطها صفر
$\mathcal{M}$	متشعّب التوزيعات	بُعده $d=\dim\Theta$
$T_\theta\mathcal{M}$	الفضاء المماس	تولّده دوالّ الدرجة
موجب محدّد	$d\theta^{\top} I d\theta>0$	$\Leftarrow$ استقلال دوالّ الدرجة (تعرّف المعلمة)
$L(\gamma)$	طول المنحنى	يُبنى عليه d_F في 7.29

الرسم

<figure> الشكل<figcaption> 1.29: كلّ نقطة على المتشعّب هي توزيع كامل؛ متّجهات المماس هي دوالّ الدرجة $\partial_i\ell$، وطولها يُقاس بفيشر لا بإقليدس.</figcaption> </figure>

البرهان

الخطوة 1 (التماثل والموجبية): $g_{ji}=g_{ij}$ بداهةً من جداء داخلي، و$d\theta^{\top} I(\theta) d\theta = \mathbb{E}\big[(\sum_i d\theta^i \partial_i \ell)^2\big] = \mathbb{E}[(d\ell)^2] \ge 0$.

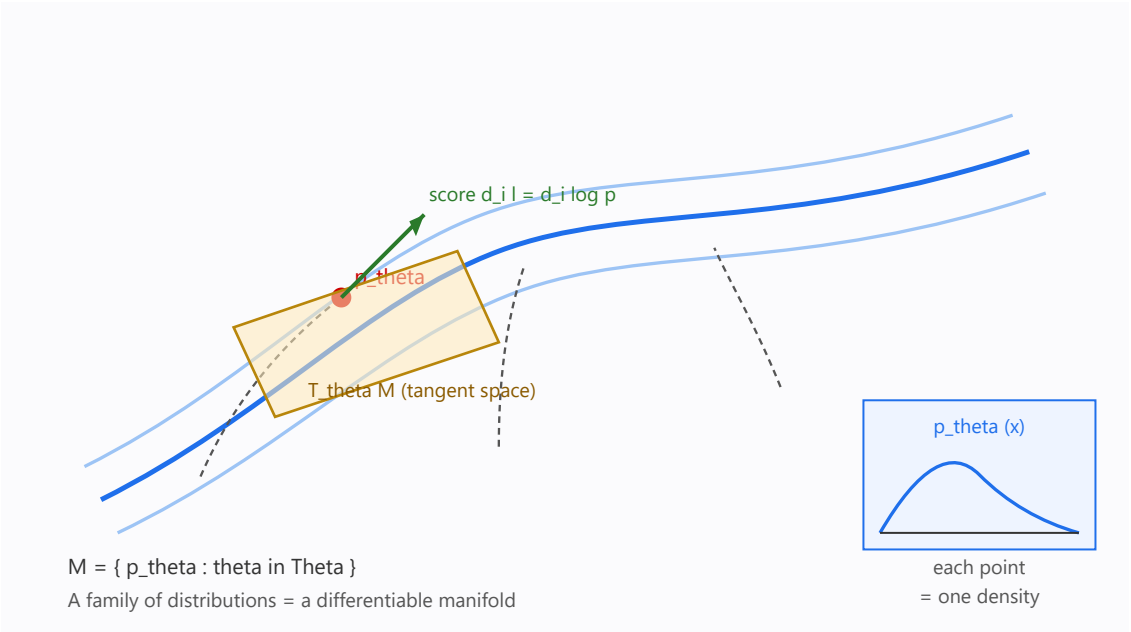
الخطوة 2 (موجبية تامّة): التساوي مع الصفر يعني $d\ell(\theta;x)=0$ لكلّ x تقريباً، أي أنّ الاتجاه $d\theta$ لا يغيّر التوزيع؛ فإذا كانت العائلة **معرَّفة** (identfiiable: $\theta\neq\theta' \Rightarrow p_\theta \neq p_{\theta'}$) فإنّ دوالّ الدرجة مستقلّة خطّياً، وI موجبة محدّدة.

الخطوة 3 (سلوك متر): بالمقارنة، g_{ij} دالةٌ ناعمة في θ (بافتراض C^2)، متماثلة، وموجبة — أي شروط متر ريماني.

الخطوة 4 (قانون التحويل): بالمقارنة المباشرة، عند تغيير الإحداثيات $\theta=\theta(\phi)$:

$$I(\phi) \;=\; J^{\top} I(\theta)\,J, \qquad J_{ai}=\frac{\partial \theta^i}{\partial \phi^a} \tag{3.29}$$

أي أنّ عنصر الطول ds^2 **ثابتٌ** (invariant) لا يتغيّر بإعادة المعْلمة — وهذه ميزة المتر الريماني الجوهرية. ■



شكل ١٠٢٩: *
فضاء التوزيعات كمتشعّب تفاضلي

خمسة عشر مثالاً محلولاً

مثال (1-2.29): برنولي — المتر في معلمة الاحتمال المعطيات: $p_\theta(x) = \theta^x(1-\theta)^{1-x}$، $x \in \{0,1\}$، $\theta = p$. المطلوب: $I(p)$ عند $p = 0.3$. الحل: الخطوة 1: $\ell = x\log p + (1-x)\log(1-p)$؛ $\partial_p \ell = \frac{x}{p} - \frac{1-x}{1-p} = \frac{x-p}{p(1-p)}$. الخطوة 2: $I(p) = \mathbb{E}[(X-p)^2]/(p(1-p))^2 = \mathrm{Var}(X)/(p(1-p))^2 = p(1-p)/(p(1-p))^2$. الخطوة 3: $I(p) = 1/(p(1-p))$؛ عند $p = 0.3$: $I = 1/0.21 \approx 4.762$. النتيجة: $ds^2 = \frac{dp^2}{p(1-p)}$؛ الطول ينفجر عند الحدود $p \to 0, 1$. الربط بالذكاء الاصطناعي: هذا سبب «تشبّع السيغمويد»: قربَ الحدود يكفي تغييرٌ ضئيل في p ليقطع مسافة معلوماتية هائلة.

مثال (2-2.29): طرفا برنولي المعطيات: $p = 0.5$ مقابل $p = 0.05$. المطلوب: المقارنة. الحل: الخطوة 1: $I(0.5) = 1/0.25 = 4$. الخطوة 2: $I(0.05) = 1/0.0475 \approx 21.05$. النتيجة: المعلومات عند الحدود أكبر بخمس مرّات: العيّنات النادرة أكثر إفادةً لكلّ وحدة تغيير في p. الربط بالذكاء الاصطناعي: لهذا تُعاقَب الاحتمالات الواثقة أكثر في التعلّم المستمر (EWC) والتدرّج الطبيعي.

مثال (3-2.29): بواسون المعطيات: $p_\lambda(x) = e^{-\lambda}\lambda^x/x!$، $\lambda = 4$. المطلوب: $I(\lambda)$. الحل: الخطوة 1: $\ell = -\lambda + x\log\lambda - \log x!$؛ $\partial_\lambda \ell = \frac{x}{\lambda} - 1 = \frac{x-\lambda}{\lambda}$. الخطوة 2: $I = \mathbb{E}[(X-\lambda)^2]/\lambda^2 = \lambda/\lambda^2 = 1/\lambda$. الخطوة 3: $I(4) = 0.25$. النتيجة: $ds^2 = d\lambda^2/\lambda$؛ تتقلّص المسافات مع كبر المعدّل. الربط بالذكاء الاصطناعي: عدّادات الأحداث النادرة (أعطال، غزوات) ذات متر أضخم — تعلّم أسرع.

مثال (4-2.29): الأُسّي (معدّل الحدوث) المعطيات: $p_\lambda(x) = \lambda e^{-\lambda x}$، $x \geq 0$، $\lambda = 2$. المطلوب: $I(\lambda)$. الحل: الخطوة 1: $\ell = \log\lambda - \lambda x$؛ $\partial_\lambda \ell = \frac{1}{\lambda} - x$. الخطوة 2: $I = \mathbb{E}[(X - 1/\lambda)^2] = \mathrm{Var}(X) = 1/\lambda^2$. الخطوة 3: $I(2) = 0.25$. النتيجة: $ds^2 = d\lambda^2/\lambda^2 \to$ في معلمة $\phi = \log\lambda$ يصير المتر ثابتاً $I(\phi) = 1$. الربط بالذكاء الاصطناعي: إعادة المعْلمة اللوغاريتمية تُحسّن شرط المتر — فكرة تتكرّر في 5.29.

مثال (5-2.29): غاوسي بمتوسط مجهول وتباين معلوم المعطيات: $\mathcal{N}(\mu, \sigma^2)$، $\sigma = 2$ معلوم. المطلوب: $I(\mu)$. الحل: الخطوة 1: $\ell = -\frac{(x-\mu)^2}{2\sigma^2} + \text{const}$؛ $\partial_\mu \ell = \frac{x-\mu}{\sigma^2}$. الخطوة 2: $I = \mathbb{E}[(X-\mu)^2]/\sigma^4 = \sigma^2/\sigma^4 = 1/\sigma^2$.

الخطوة 3: $I = 1/4 = 0.25$. النتيجة: $ds^2 = d\mu^2/\sigma^2$: الطول = المسافة بالانحرافات المعيارية. الربط بالذكاء الاصطناعي: انحدارٌ بضجيج عالٍ ⇒ متر صغير ⇒ خطوات تدرّج طبيعي كبيرة مسموحة.

مثال (29.2-6): الغاوسي بمعلمتين المعطيات: $\theta = (\mu, \sigma)$، $\sigma = 3$. المطلوب: مصفوفة المتر. الحل: الخطوة 1: $\partial_\mu \ell = \frac{x-\mu}{\sigma^2}$، $\partial_\sigma \ell = -\frac{1}{\sigma} + \frac{(x-\mu)^2}{\sigma^3}$. الخطوة 2: $\mathbb{E}[\partial_\mu \ell \partial_\sigma \ell] = \mathbb{E}[(X-\mu)^3]/\sigma^5 - \mathbb{E}[X-\mu]/\sigma^3 = 0$ (العزم الثالث للغاوسي صفر). الخطوة 3: $I_{\mu\mu} = 1/\sigma^2$، $I_{\sigma\sigma} = \mathbb{E}[(Z^2-1)^2]/\sigma^2 = 2/\sigma^2$ مع $Z \sim \mathcal{N}(0,1)$. النتيجة: $I = \mathrm{diag}(1/\sigma^2, 2/\sigma^2) = \mathrm{diag}(1/9, 2/9) \approx \mathrm{diag}(0.111, 0.222)$. الربط بالذكاء الاصطناعي: محور التباين «أثقل» بمعامل 2 — لذلك تختلف خطوة التدرّج الطبيعي لمعلمة التباين عنها للمتوسط.

مثال (29.2-7): ثبات المتر تحت إعادة المعْلمة (لوغيت) المعطيات: برنولي بـ $\phi = \log \frac{p}{1-p}$، $p = 0.5$. المطلوب: $I(\phi)$ من $I(p)$ بالتحويل. الحل: الخطوة 1: $I(p) = 1/(p(1-p))$، $dp/d\phi = p(1-p)$. الخطوة 2: $I(\phi) = I(p)(dp/d\phi)^2 = \frac{1}{p(1-p)}(p(1-p))^2 = p(1-p)$. الخطوة 3: عند $p = 0.5$: $I(\phi) = 0.25$. النتيجة: المتر في إحداثيات اللوغيت هو «تباين برنولي» نفسه — محدود بـ 0.25 بدل الانفجار. الربط بالذكاء الاصطناعي: هذا متر مخرجات الشبكة قبل السيغمويد: $s(1-s)$ — أساس التدرّج الطبيعي لطبقة التصنيف.

مثال (29.2-8): عائلة الموضع (location family) المعطيات: $p_\theta(x) = f(x-\theta)$، $f = \mathcal{N}(0,1)$. المطلوب: هل يعتمد I على θ؟ الحل: الخطوة 1: $\partial_\theta \ell = -f'(x-\theta)/f(x-\theta)$. الخطوة 2: بتغيير المتغيّر $u = x - \theta$: $I(\theta) = \int (f'(u)^2/f(u))du$ — لا يحتوي θ. النتيجة: متر عائلات الموضع **ثابت** (متجانس: transl-invariant). $I = 1$ للغاوسي المعياري. الربط بالذكاء الاصطناعي: تحويلاتٌ تحافظ على بنية المتر (مثل انزياحات CNN تُبقي هندسة المعلومة كما هي.

مثال (29.2-9): فقدان التعرّف على المعلمة ⇒ متر شاذّ المعطيات: $p_\theta = \mathcal{N}(\theta^1 + \theta^2, 1)$، $\theta \in \mathbb{R}^2$. المطلوب: رتبة I. الحل: الخطوة 1: $\partial_1 \ell = \partial_2 \ell = (x-\mu)$ ⇒ متّجهات الدرجة متوازية. الخطوة 2: $I = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$، قيمها الذاتية $\{2, 0\}$. النتيجة: المتر شاذّ؛ (singular) البعد الفعلي للمتشعّب 1 لا 2. الربط بالذكاء الاصطناعي: الشبكات العميقة مليئة بهذا التكرار (أوزان قابلة لإعادة القياس) ⇒ I شاذّة دائماً وتحتاج تخميداً.

مثال (29.2-10): انتهاك الانتظام — المنتظم على $(0, \theta)$ المعطيات: $p_\theta(x) = 1/\theta$ على $(0, \theta)$. المطلوب: هل تنطبق صيغة فيشر؟ الحل: الخطوة 1: $\partial_\theta \ell = -1/\theta$ داخل الدعامة، $\int_0^\theta (1/\theta^2)(1/\theta)dx = 1/\theta^2$ صورياً. الخطوة 2: لكنّ الدعامة تعتمد على θ، فتبادل المشتقّة والتكامل **غير مسموح**. الخطوة 3: المُقدّر الأمثل $\hat{\theta} = \max_i X_i$ بتباين $\approx \theta^2/n^2$، أفضل من حدّ فيشر θ^2/n. النتيجة: صيغة (29.1) تعطي رقماً بلا معنى حدّي صحيح؛ شرط الانتظام جوهري. الربط بالذكاء الاصطناعي: النماذج ذات الدعامة المتغيّرة (بعض نماذج التوليد، ترتيب الأحداث) تكسر حدود فيشر الكلاسيكية.

مثال (29.2-11): سوفتماكس / التوزيع الفئوي المعطيات: $p = (0.5, 0.25, 0.25)$ على 3 أصناف، المعلمة هي المتجه p مع القيد $\sum p_k = 1$. المطلوب: I ورتبتها. الحل: الخطوة 1: $\partial_{p_k} \ell = x_k/p_k$ (بإسقاط على القيد) ⇒ $I_{kj} = \mathbb{E}[X_k X_j]/(p_k p_j)$ للمكوّنات الحرّة. الخطوة 2: في الإحداثيات الطبيعية $z_k = \log p_k$: $I = \mathrm{diag}(p) - pp^\top$. الخطوة 3: $I = \mathrm{diag}(0.5, 0.25, 0.25) - \begin{pmatrix} 0.25 & 0.125 & 0.125 \\ 0.125 & 0.0625 & 0.0625 \\ 0.125 & 0.0625 & 0.0625 \end{pmatrix}$. الخطوة 4: والأهمّ: $I\mathbf{1} = 0$ ⇒ الرتبة 2 وليس 3 (البعد الفعلي لل simplices هو $K-1$). النتيجة: رتبة I هي $K-1$؛ نعمل على فضاء المماس $\sum v_k = 0$ أو نستخدم معكوساً شبه عام (pseudo-inverse). الربط بالذكاء الاصطناعي: لهذا لا نعكس متر السوفتماكس مباشرة بل نضيف تخميداً λI (انظر 29.5-13).

مثال (29.2-12): الانحدار الخطي الغاوسي المعطيات: $y = x^\top \beta + \varepsilon$، $\varepsilon \sim \mathcal{N}(0, \sigma^2)$، $\sigma = 1$، وتصميم X بأعمدة x_i. المطلوب: $I(\beta)$. الحل: الخطوة 1: $\nabla_\beta \ell = (y - x^\top \beta)x/\sigma^2$. الخطوة 2: $I = \mathbb{E}[xx^\top]/\sigma^2$ ⇒

تجريبياً $I = X^\top X/\sigma^2$. النتيجة: متر المعلومات = مصفوفة التصميم (بمقياس $1/\sigma^2$). الربط بالذكاء الاصطناعي: سوء شرط $X^\top X$ (= سوء شرط المتر) هو بالضبط سبب بطء التدرّج؛ التدرّج الطبيعي يقلبه.

مثال (13-2.29): الغاوسي متعدد المتغيّرات — متوسط مجهول المعطيات: $\Sigma = \mathrm{diag}(4,\,1)$. المطلوب: $I(\mu)$. الحل: الخطوة 1: $\nabla_\mu \ell = \Sigma^{-1}(x-\mu)$. الخطوة 2: $I = \Sigma^{-1}\mathbb{E}[(X-\mu)(X-\mu)^\top]\Sigma^{-1} = \Sigma^{-1}$. الخطوة 3: $I = \mathrm{diag}(0.25,\,1)$. النتيجة: الاتجاه ذو التباين الصغير (المحور الثاني) معلوماته أكبر بأربع مرّات. الربط بالذكاء الاصطناعي: مسافة ماهالانوبيس $\Delta^\top\Sigma^{-1}\Delta$ ليست إلا طول فيشر (ستثبتها 7.29).

مثال (14-2.29): العائلة الأُسّية — المتر = تباين الإحصاء الكافي المعطيات: $p_\theta(x) = h(x)\exp(\theta^\top T(x) - \psi(\theta))$ بصيغة مغلقة. الحل: الخطوة 1: $\partial_i \ell = T_i(x) - \partial_i\psi(\theta)$، و$\Rightarrow \mathbb{E}[\partial_i \ell] = 0$ $\nabla\psi = \mathbb{E}[T]$. الخطوة 2: $I_{ij} = \mathbb{E}[(T_i-\mu_i)(T_j-\mu_j)] = \mathrm{Cov}(T_i,T_j)$. ومن الخطوة 1 أيضاً $I = \nabla^2\psi \Rightarrow \partial_i\partial_j\psi = \partial_i\mu_j = \mathrm{Cov}(T_i,T_j)$. النتيجة: متر العائلة الأُسّية = هِسّية كمون لوغاريتم القاسم = تباين الإحصاء الكافي. الربط بالذكاء الاصطناعي: هذا هو سبب أنّ التدرّج الطبيعي في الشبكات ذي مخرجات أُسّية يتحوّل إلى تحديثٍ بسيط في «إحداثيات التوقّع».

مثال (15-2.29): تراكم المعلومة مع حجم العيّنة المعطيات: $n = 100$ ملاحظة مستقلة من $\mathcal{N}(\mu, 4)$. المطلوب: معلومة العيّنة كلها. الحل: الخطوة 1: معلومة ملاحظة واحدة $I_1 = 1/\sigma^2 = 0.25$. الخطوة 2: للعيّنات المستقلة تتجمّع الدرجات: $I_n = nI_1 = 25$. النتيجة: $ds_n^2 = n\,ds_1^2$؛ المتشعّب «ينكمش» بمعامل $\sqrt{n}$. الربط بالذكاء الاصطناعي: هذا هو الأصل الهندسي ل rate $\sqrt{n}$ في الإحصاء، ولِكون حجم الدفعة يضخّم المتر في التدرّج الطبيعي.

أخطاء شائعة

- اعتبار I هِسّيةً للدالة الهدف (هي هِسّيةُ **توقّع** اللوغاريتم الاحتمالي، لا للخسارة التجريبية).
- استخدام $I(\theta)$ المكتوبة بالصيغة الصورية خارج شروط الانتظام (مثال 10-2.29).
- نسيان أنّ الرتبة قد تكون ناقصة (قيد السوفتماكس، عدم التعرّف).
- الخلط بين **معلومة فيشر** (متر) و**الإنتروبيا** (مقياس عدم اليقين)؛ لا علاقة مباشرة بينهما إلا في حالات خاصّة (مثل متلازمة دي بروين في 15-4.29).
- الظنّ أنّ وحدات I لا تتغيّر بالمعلمة: هي تتغيّر (قانون 3.29).

المبرهنة: لتكن العائلة منتظمة. عندئذٍ

$$D_{\mathrm{KL}}\big(p_\theta \,\|\, p_{\theta+d\theta}\big) \;=\; \frac{1}{2}\, d\theta^\top I(\theta)\, d\theta \;+\; O(\|d\theta\|^3) \tag{4.29}$$

$$I(\theta) \;=\; \mathbb{E}\big[\nabla\ell\,\nabla\ell^\top\big] \;=\; -\,\mathbb{E}\big[\nabla^2\ell\big] \tag{5.29}$$

$$\mathbb{E}_{p_\theta}\big[\nabla_\theta \ell(\theta;X)\big] \;=\; 0 \tag{6.29}$$

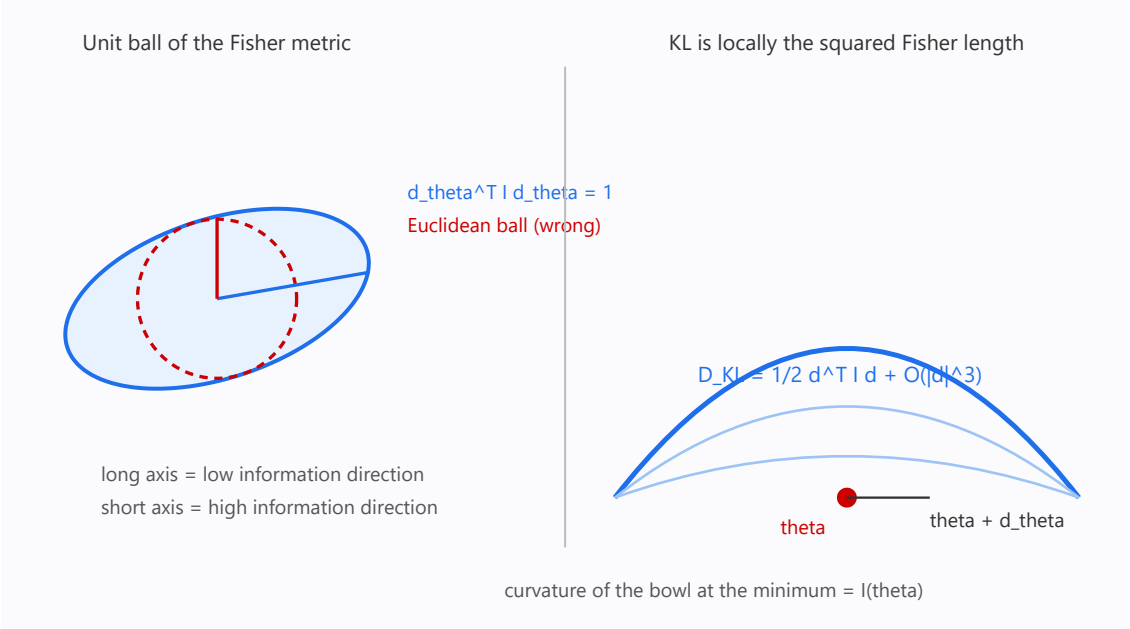
أي أنّ فيشر هو **الهِسّية المحلّية لتباعد KL** عند القطر، وKL «مربع مسافة» لا مسافة (لا يتماثل ولا يحقق متراجحة المثلّث).

جدول الرموز

الرمز	المعنى	ملاحظة
$D(p\|\|q)$	تباعد كولباك–لايبلر	من الفصل 27
$O(\|\|d\|\|^3)$	حدّ من الرتبة الثالثة	يختفي عند $d \to 0$
$\nabla^2 \ell$	هِسّية اللوغاريتم الاحتمالي	سالبها = فيشر
القطر	$D = 0$ حيث $\theta = \theta'$	المتر يُقاس عنده فقط
لامتغيّر	ds^2	لا يتغيّر بإعادة المُعْلمة

الرسم

<figure> الشكل<figcaption> 2.29: يساراً: كرة الوحدة في متر فيشر (إهليلج) مقابل الكرة الإقليدية؛ يميناً: وعاء KL



شكل ٢٩.٢: *
KL بوصفه نصف مربع طول فيشر

وانحناؤه عند القطر = $I(\theta)$.</figcaption></figure>

البرهان

الخطوة 1 (متوسط الدرجة صفر): $\mathbb{E}[\partial_i \ell] = \int \frac{\partial_i p_\theta}{p_\theta} p_\theta \, d\mu = \partial_i \int p_\theta \, d\mu = \partial_i 1 = 0$ — بشرط تبادل المشتقّة والتكامل. هذا (6.29).

الخطوة 2 (التكافؤ 5.29): باشتقاق (6.29) بالنسبة لـ θ^j: $\partial_j \mathbb{E}[\partial_i \ell] = 0$. وبصراحة:

$$0 = \partial_j \int (\partial_i \ell)\, p_\theta \, d\mu = \int (\partial_j \partial_i \ell)\, p_\theta \, d\mu + \int (\partial_i \ell)(\partial_j p_\theta)\, d\mu$$

والحدّ الثاني $\int (\partial_i \ell)(\partial_j \ell) p_\theta \, d\mu = \mathbb{E}[\partial_i \ell \, \partial_j \ell]$، لأن $\partial_j p_\theta = p_\theta \, \partial_j \ell$. ومنه $I = -\mathbb{E}[\nabla^2 \ell]$ بالترتيب المعاكس. ■

الخطوة 3 (الهِسّية المحلّية لـ KL): عرّف $f(d) = D_{\mathrm{KL}}(p_\theta \| p_{\theta+d}) = \mathbb{E}_{p_\theta}[\ell(\theta) - \ell(\theta + d)]$. فإنّ $\nabla f(0) = -\mathbb{E}[\nabla \ell] = 0$ بالخطوة 1، و

$$\nabla^2 f(0) \;=\; -\mathbb{E}\big[\nabla^2 \ell(\theta)\big] \;=\; I(\theta)$$

بتايلور حول $d=0$: $f(d)=f(0)+\nabla f(0)^\top d+\tfrac12 d^\top\nabla^2 f(0)d+O(\|d\|^3)=\tfrac12 d^\top I d+O(\|d\|^3)$. ■

الخطوة 4 (النتيجة الهندسية): KL لا يتماثل، لكنّ حدّه من الرتبة الثانية **متماثل** — لأنّ عدم التماثل يظهر في الرتبة الثالثة، لذلك يُنتج متراً (ريمانياً) ولا يُنتج متراً عالمياً (انظر 7.29). ■

خمسة عشر مثالاً محلولاً

مثال (1-3.29): برنولي — تحقّق عددي للصيغة المعطيات: $p=0.5$، $q=p+\varepsilon$ بـ $\varepsilon=0.01$. المطلوب: مقارنة $D(p\|q)$ بـ $\tfrac12 I\varepsilon^2$. الحل: الخطوة 1: $I(0.5)=4$. الخطوة 2: التقدير الموضعي $\tfrac12\cdot 4\cdot 10^{-4}=2\times10^{-4}$ nats. الخطوة 3: الحساب الدقيق: $D=0.5\ln\frac{0.5}{0.51}+0.5\ln\frac{0.5}{0.49}=0.5(-0.019803+0.020203)=2.0\times10^{-4}$. النتيجة: تطابق حتى أربع مراتب عشرية. الربط بالذكاء الاصطناعي: تقريب منطقة الثقة (TRPO) مبرَّر رياضياً للخطوات الصغيرة فقط.

مثال (2-3.29): الانحراف عند الاقتراب من الحدود المعطيات: $p=0.1$، $\varepsilon=0.01$. المطلوب: الدقّة الموضعية. الحل: الخطوة 1: $I(0.1)=1/0.09=11.111$. الخطوة 2: التقدير $\tfrac12\cdot11.111\cdot10^{-4}=5.556\times10^{-4}$. الخطوة 3: الدقيق: $0.9\ln\frac{0.9}{0.89}+0.1\ln\frac{0.1}{0.11}=0.010056-0.009531=5.25\times10^{-4}$. النتيجة: فرق نسبي $\approx 6\%$ — الحدّ الثالث يكبر قرب الحدود. الربط بالذكاء الاصطناعي: في الاحتمالات الصغيرة (نماذج اللغة!) يجب تخفيض خطوة منطقة الثقة.

مثال (3-3.29): الغاوسي — حالة التطابق التام المعطيات: $\mathcal{N}(\mu_1,1)$ مقابل $\mathcal{N}(\mu_1+\Delta,1)$. المطلوب: $D(\mu\|\mu+\Delta)$. الحل: الخطوة 1: $\Delta^2/2=\Delta^2/(2\sigma^2)$. الخطوة 2: $\tfrac12 I\Delta^2=\tfrac12(1/\sigma^2)\Delta^2=\Delta^2/2$. النتيجة: تطابق تامّ لكلّ Δ (لأنّ KL تربيعي في Δ). الربط بالذكاء الاصطناعي: عائلات الموضع الغاوسية هي أبسط مختبر لمناطق الثقة.

مثال (4-3.29): تحقّق تكافؤ الهسّية في بواسون المعطيات: $p_\lambda(x)=e^{-\lambda}\lambda^x/x!$. المطلوب: $-\mathbb{E}[\partial_\lambda^2\ell]$. الحل: الخطوة 1: $\partial_\lambda\ell=x/\lambda-1\Rightarrow\partial_\lambda^2\ell=-x/\lambda^2$. الخطوة 2: $-\mathbb{E}[-X/\lambda^2]=\lambda/\lambda^2=1/\lambda$. النتيجة: يطابق $I=\mathbb{E}[(X-\lambda)^2]/\lambda^2=1/\lambda$ من 2-3.29. الربط بالذكاء الاصطناعي: الصيغة الثانية (الهسّية) أسهل حساباً في الشفرة التفاضلية الآلية (من الفصل 8/9).

مثال (5-3.29): الغاوسي بمعلمتين — تحقّق الهسّية المعطيات: $\theta=(\mu,\sigma)$. المطلوب: $-\mathbb{E}[\nabla^2\ell]$. الحل: الخطوة 1: $\partial_\mu^2\ell=-1/\sigma^2\Rightarrow -\mathbb{E}=1/\sigma^2$ ✓. الخطوة 2: $-\mathbb{E}=-(-1/\sigma^2)=\frac{1}{\sigma^2}\Rightarrow\partial_\sigma^2\ell=\frac{1}{\sigma^2}-\frac{3(x-\mu)^2}{\sigma^4}$. $-\mathbb{E}=-\frac{1}{\sigma^2}+\frac{3\sigma^2}{\sigma^4}=\frac{2}{\sigma^2}$ ✓. الخطوة 3: المكوّنة المختلطة $\partial_\mu\partial_\sigma\ell=-2(x-\mu)/\sigma^3\Rightarrow$ توقّعها صفر ✓. النتيجة: طابقنا مصفوفة 6-2.29 بالصيغتين معاً. الربط بالذكاء الاصطناعي: فحصٌ ممتاز لأيّ مشتقّة آلية: قارن الهسّية بجداء الدرجات.

مثال (6-3.29): إعادة المعْلمة في بواسون (صلة GLM المعطيات: $\lambda=e^\phi$ (رابط لوغاريتمي في انحدار بواسون)، $\lambda=3$. المطلوب: $I(\phi)$. الحل: الخطوة 1: $I(\lambda)=1/\lambda=1/3$، $d\lambda/d\phi=\lambda=3$. الخطوة 2: $I(\phi)=I(\lambda)(d\lambda/d\phi)^2=(1/3)(9)=3$. النتيجة: $I(\phi)=\lambda$: المتر في إحداثيات الرابط الكنسي = المتوسط المتوقّع. الربط بالذكاء الاصطناعي: هذا بالضبط مصفوفة الأوزان في فيشر/IRLS سكورينغ لتلك النماذج.

مثال (7-3.29): إعادة معْلمة التباين باللوغاريتم المعطيات: $\tau=\log\sigma$ في $\mathcal{N}(\mu,\sigma^2)$. المطلوب: I في (μ,τ). الحل: الخطوة 1: $I_{\sigma\sigma}=2/\sigma^2$، $d\sigma/d\tau=\sigma$. الخطوة 2: $I_{\tau\tau}=(2/\sigma^2)\sigma^2=2$ — **ثابت**. الخطوة 3: $I_{\mu\tau}=0$ (تبقى متعامدة)، $I_{\mu\mu}=1/\sigma^2=e^{-2\tau}$. النتيجة: إعادة المعْلمة حسّنت الشرط جذرياً؛ صار المتر في اتجاه المقياس ثابتاً. الربط بالذكاء الاصطناعي: لهذا تُعلِّم الأُسّيات والانحرافات المعيارية دوماً باللوغاريتم (softplus) في الممارسة.

مثال (8-3.29): تماثل الحدّ الثاني رغم لاتماثل KL المعطيات: نفس $p=0.5$، $\varepsilon=0.01$. المطلوب: $D(p\|q)$ مقابل $D(q\|p)$. الحل: الخطوة 1: $D(p\|q)=2.00\times10^{-4}$ (من 1-3.29). الخطوة 2: $D(q\|p)=0.51\ln\frac{0.51}{0.5}+0.49\ln\frac{0.49}{0.5}=0.51(0.019803)+0.49(-0.020203)=10.099-9.899=2.00\times10^{-4}$

nats. النتيجة: متطابقان حتى الرتبة الثانية، الفرق يظهر عند $O(\varepsilon^3)$. الربط بالذكاء الاصطناعي: لا يجوز استبدال KL بمتر في التباعدات الكبيرة — خطأ شائع في تدريب GAN/VAE.

مثال (29.3-9): متى يفشل التقريب الموضعي؟ المعطيات: برنولي $p = 0.5$ مقابل $q = 0.9$. المطلوب: مقارنة التقريب بالدقيق. الحل: الخطوة 1: $\frac{1}{2} I \varepsilon^2 = \frac{1}{2} \cdot 4 \cdot (0.4)^2 = 0.32$ nats. الخطوة 2: الدقيق $= 0.5 \ln(0.5/0.9) + 0.5 \ln(0.5/0.1) = -0.2939 + 0.8047 = 0.5108$ nats. النتيجة: خطأ نسبي $37\% \approx$ — التقريب الموضعي انهار. الربط بالذكاء الاصطناعي: منطقة ثقة بـ $\varepsilon = 0.01$ في KL مشدّدة جدّاً، لذلك تُقاس القيود **تجريبياً** لا بالتقريب الموضعي.

مثال (29.3-10): منطقة الثقة في RL (TRPO) المعطيات: سياسة π_θ، قيد $\mathbb{E}[D_{\mathrm{KL}}(\pi_{\theta_{\text{old}}} \| \pi_\theta)] \le \delta = 0.01$. المطلوب: تفسير هندسي. الحل: الخطوة 1: القيد يعني $\frac{1}{2} d^\top I d \le \delta$ — كرة في متر المعلومة. الخطوة 2: I هنا متر فيشر للسياسة: $I = \mathbb{E}_{s,a}[\nabla \log \pi \, \nabla \log \pi^\top]$. النتيجة: الخطوة المسموحة في اتجاهٍ ذي معلومة عالية أصغر بكثير. الربط بالذكاء الاصطناعي: هذا جوهر TRPO/PPO ومنع الانهيار السياسي (policy collapse).

مثال (29.3-11): فيشر سكورينغ مقابل نيوتن المعطيات: تعظيم لوغاريتم الاحتمالي $\mathcal{L}(\theta)$. المطلوب: الفرق بين الطريقتين. الحل: الخطوة 1: نيوتن: $\theta \leftarrow \theta - H^{-1} \nabla \mathcal{L}$ بـ $H = \nabla^2 \mathcal{L}$ (تجريبي، قد يكون غير سالب محدّد). الخطوة 2: فيشر سكورينغ: يستبدل H بـ $-nI(\theta)$ (توقّعها)، وهي سالبة محدّدة دائماً. النتيجة: فيشر سكورينغ = نيوتن «باستقرار مضمون»، ويطابقه في العائلات الأُسّية بالرابط الكنسي. الربط بالذكاء الاصطناعي: Gauss–Newton في الشبكات هو تقريب فيشر بهذا المعنى (قارن K-FAC في 29.5).

مثال (29.3-12): الإحداثيات المثبّتة للتباين المعطيات: برنولي بـ $p = \sin^2 \varphi$. المطلوب: $I(\varphi)$. الحل: الخطوة 1: $dp/d\varphi = 2 \sin \varphi \cos \varphi = 2\sqrt{p(1-p)}$. الخطوة 2: $I(\varphi) = \frac{1}{p(1-p)} \cdot 4p(1-p) = 4$. النتيجة: متر **ثابت** = 4، أي أنّ المتشعّب في هذه الإحداثيات **قوسٌ من دائرة نصف قطرها 2** ($ds = 2\, d\varphi$). الربط بالذكاء الاصطناعي: هذه هي الإحداثيات الجيوديسية التي تعطي مسافة فيشر–راو (ستُستثمر في 29.7).

مثال (29.3-13): شرط المتر في شبكة مصنّفة المعطيات: وحدة سيغمويد باحتمال $p = 0.01$ (تشبّع). المطلوب: رقم الشرط الموضعي. الحل: الخطوة 1: $I(0.01) = 1/0.0099 \approx 101$ مقابل $I(0.5) = 4$. الخطوة 2: النسبة ≈ 25. النتيجة: اتجاه الوحدة المشبّعة «أثقل» بـ 25 مرّة $\Rightarrow$ إقليدس يوزّع الخطوة خطأً. الربط بالذكاء الاصطناعي: تفسير هندسي لبطء التعلّم في الوحدات المشبّعة قبل التطبيع (BatchNorm).

مثال (29.3-14): متر السوفتماكس في التصنيف المعطيات: طبقة سوفتماكس بـ 10 أصناف، s متجه الاحتمالات. المطلوب: صيغة فيشر في لوجِتات z. الحل: الخطوة 1: الإحداثيات الطبيعية هي z؛ $T(x) =$ متجه واحد ساخن. الخطوة 2: بـ 29.2-14: $I = \mathrm{Cov}(T) = \mathrm{diag}(s) - ss^\top$ (رتبة 9). النتيجة: متر المخرجات = تباين التوزيع المتوقّع — نفس مصفوفة يعقوب السوفتماكس من الفصل 9. الربط بالذكاء الاصطناعي: تكرار هذه البنية في كل طبقة هو ما تستغلّه K-FAC (29.5).

مثال (29.3-15): فيشر الحقيقي مقابل فيشر التجريبي المعطيات: تصنيفٌ بـ K أصناف وخسارة إنتروبيا تقاطعية. المطلوب: أيّ متر نحسب؟ الحل: الخطوة 1: **فيشر الحقيقي**: $I = \mathbb{E}_x \mathbb{E}_{y \sim p_\theta(y|x)}[\nabla \ell \, \nabla \ell^\top]$ — بالتوزيع الذي يولّده النموذج. الخطوة 2: **فيشر التجريبي**: $\frac{1}{N} \sum_n \nabla \ell(y_n) \nabla \ell(y_n)^\top$ — بالتسميات المرصودة. الخطوة 3: يتطابقان فقط إذا كان النموذج يولّد التسميات نفسها (ملاءمة تامّة). النتيجة: في منتصف التدريب يختلفان جوهريّاً؛ K-FAC يستخدم الحقيقي، و Adam يشبه التجريبي القطري. الربط بالذكاء الاصطناعي: سببٌ نظري لاختلاف سلوك المُحسِّنات التكيفية عن التدرّج الطبيعي الصريح.

أخطاء شائعة

- استخدام تقريب $\frac{1}{2}d^\top I d$ لتباعدات كبيرة (فشل بنسبة 37% في مثال 3.29-9).
- الخلط بين $I(\theta)$ و$-\nabla^2 \mathcal{L}$ التجريبية (الهِسّية قد لا تكون سالبة محدّدة).
- نسيان أنّ (5.29) يحتاج توقّعاً تحت p_θ **نفسها** لا تحت توزيع البيانات.
- افتراض أنّ KL يولّد متراً عالمياً؛ هو يولّد متراً موضعياً فقط (الفرق يظهر في 7.29).
- حساب I في إحداثيات سيّئة الشرط ثمّ لوم المُحسِّن (الحل: إعادة المعْلمة كما في 3.29-7).

المبرهنة: ليكن $\hat\theta$ مقدّراً **غير متحيّز** لـ θ من عيّنة حجمها n، في عائلة منتظمة. فإنّ

$$\operatorname{Cov}_\theta(\hat\theta) \;\succeq\; I_n(\theta)^{-1}, \qquad \operatorname{Var}_\theta(\hat\theta_i) \;\geq\; \big[I_n(\theta)^{-1}\big]_{ii} \tag{7.29}$$

وإذا كان للمقدّر انحياز $b(\theta) = \mathbb{E}[\hat\theta] - \theta$، فالصيغة العامة

$$\operatorname{Var}_\theta(\hat\theta) \;\geq\; \frac{\big(1 + b'(\theta)\big)^2}{I_n(\theta)} \tag{8.29}$$

كما أنّ مقدّر الاحتمال الأعظم (MLE) يحقّق الحدّ **مقارباً**: $\sqrt{n}\,(\hat\theta_{\text{MLE}} - \theta_0) \xrightarrow{d} \mathcal{N}\big(0,\; I_1(\theta_0)^{-1}\big)$.

جدول الرموز

الرمز	المعنى	ملاحظة
$\succeq$	ترتيب لوفنر (أي $A - B$ موجبة نصف محدّدة)	للمصفوفات
$I_n = nI_1$	معلومة العيّنة	استقلال
غير متحيّز	$\mathbb{E}[\hat\theta] = \theta$	وإلا استخدم (8.29)
كفاءة	نسبة الحدّ إلى التباين الفعلي	1 = كفء
$b'(\theta)$	مشتقّة الانحياز	المقدّرات المتحيّزة قد تتجاوز الحدّ

الرسم

<figure> الشكل<figcaption> 3.29: انحناء قمّة اللوغاريتم الاحتمالي هو معلومة فيشر؛ كلّما كانت القمّة أحدّ، صغر التباين الممكن لأيّ مقدّر.</figcaption> </figure>

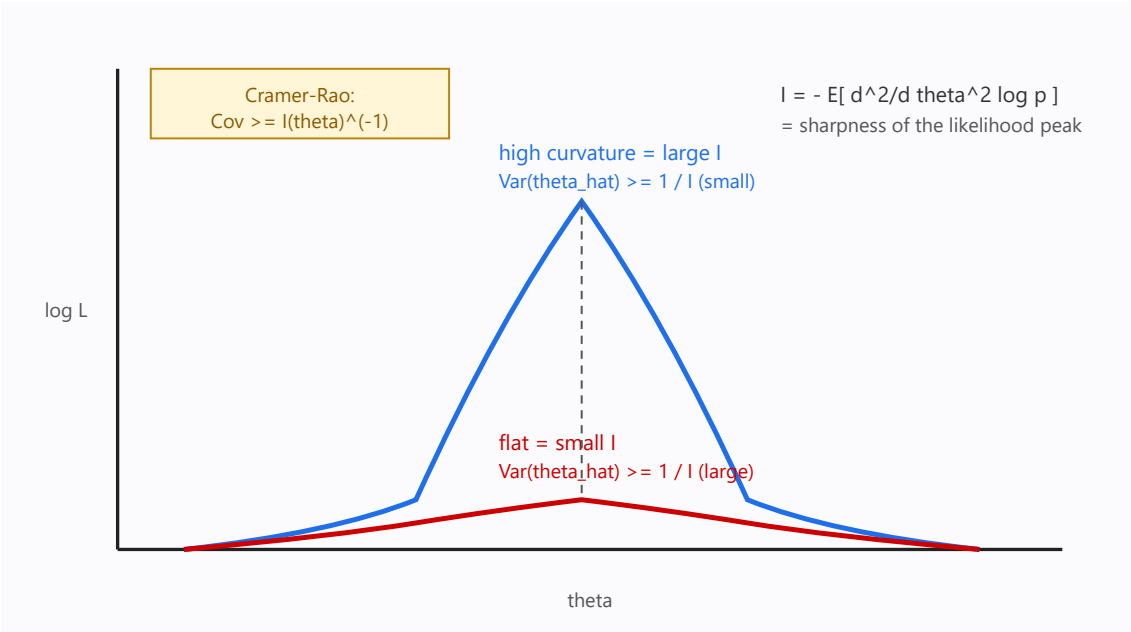
البرهان (مخطّط)

الخطوة 1: من (6.29)، $\mathbb{E}[\hat\theta_i] = \theta_i \Rightarrow$ باشتقاق: $\operatorname{Cov}(\hat\theta_i, s_j) = \delta_{ij} \Rightarrow \partial_j \int \hat\theta_i \, p \, d\mu = \delta_{ij}$ حيث $s = \nabla \ell$ متّجه الدرجة. أي $\operatorname{Cov}(\hat\theta, S) = I_d$.

الخطوة 2: للمتّجه العشوائي $(\hat\theta,\, S)$ مصفوفة التغاير الموجبة:

$$\begin{pmatrix} \operatorname{Cov}(\hat\theta) & I \\ I & I_n(\theta) \end{pmatrix} \succeq 0$$

الخطوة 3: بأخذ مكمّل شور (Schur complement) بالنسبة للكتلة السفلية: $\operatorname{Cov}(\hat\theta) - I \cdot I_n^{-1} \cdot I \;\succeq\; 0$، وهو (7.29). $\blacksquare$



شكل ٢٩.٣: *
مترابحة كرامير-راو

الخطوة 4 (الحالة المتحيّزة): يستبدل الطرف الأيمن بـ $\nabla_\theta \mathbb{E}[\hat{\theta}]$ فتظهر $(1+b')^2$ عوضاً عن 1.

الخطوة 5 (مقاربية MLE): بتوسيع تايلور لشرط الأمثلية $0 = \nabla \ell_n(\hat{\theta})$ حول θ_0: $\hat{\theta} - \theta_0 \approx -(\nabla^2 \ell_n)^{-1} \nabla \ell_n(\theta_0)$، وبقانون الأعداد الكبرى $-\nabla^2 \ell_n / n \to I_1$ وبـ CLT $\nabla \ell_n / \sqrt{n} \to \mathcal{N}(0, I_1)$ $\Rightarrow$ النتيجة. $\blacksquare$

خمسة عشر مثالاً محلولاً

مثال (29-4.1): استطلاع رأي — دقّة تقدير نسبة المعطيات: $n = 1000$، التقدير $\hat{p} = 0.5$. المطلوب: أصغر تباين وانحراف معياري ممكن. الحل: الخطوة 1: $I_1(p) = 1/(p(1-p)) = 4$، $I_n = 4000$. الخطوة 2: $\text{Var} \geq 1/4000 = 2.5 \times 10^{-4}$. الخطوة 3: الانحراف المعياري ≥ 0.0158. النتيجة: هامش $\pm 1.96 \times 0.0158 \approx \pm 3.1\%$. الربط بالذكاء الاصطناعي: حدود دقّة أيّ نموذج تقدير احتمال، مهما بلغت قوّته الحسابية.

مثال (29-4.2): عدّ أحداث نادرة (معدّل بواسون) المعطيات: $n = 50$ فترة، $\lambda = 4$ حادث/فترة. المطلوب: حدّ التباين. الحل: الخطوة 1: $I_1 = 1/\lambda = 0.25$، $I_n = 12.5$. الخطوة 2: $\text{Var} \geq 1/12.5 = 0.08 \Rightarrow$ انحراف معياري ≥ 0.283. النتيجة: دقّة نسبية $0.283/4 \approx 7\%$. الربط بالذكاء الاصطناعي: كشف الشذوذ بمعدّلات منخفضة يحتاج عيّنات أطول بنسبة $1/\lambda$.

مثال (29-4.3): تقدير متوسط بتباين معلوم المعطيات: $n = 25$، $\sigma = 2$. المطلوب: حدّ تباين $\hat{\mu}$ وهل يبلغه MLE؟ الحل: الخطوة 1: $I_1 = 1/\sigma^2 = 0.25$، $I_n = 6.25$، $\text{Var} \geq 0.16 \Rightarrow \text{sd} \geq 0.4$. الخطوة 2: $\bar{X}$ غير متحيّز بتباين $\sigma^2/n = 4/25 = 0.16$. النتيجة: الحدّ **ملغوم** (attained) تماماً. الربط بالذكاء الاصطناعي: متوسط الدفعة (batch mean) مقدّر كفء — لا خوارزمية تتفوّق عليه إحصائيّاً.

مثال (29-4.4): تقدير التباين المعطيات: $n = 100$، $\sigma^2 = 4$. المطلوب: حدّ تباين $\widehat{\sigma^2}$. الحل: الخطوة 1: في معلمة σ^2: $I_1(\sigma^2) = 1/(2\sigma^4) = 1/32$، $I_n = 100/32 = 3.125$. الخطوة 2: $\text{Var} \geq 1/3.125 = 0.32$. النتيجة: $\text{sd} \geq 0.566$ لتباين قيمته 4 (نسبة 14%). الربط بالذكاء الاصطناعي: تقدير مصفوفات التغاير أبطأ بكثير من تقدير المتوسطات — سبب شعبية التقديرات القطرية.

مثال (29-4.5): تخطيط حجم العيّنة المعطيات: نريد تقدير $p \approx 0.5$ بخطأ ≤ 0.01 بثقة 95%. المطلوب: n. الحل:

الخطوة 1: $1.96\sqrt{p(1-p)/n} \le 0.01$. الخطوة 2: $n \ge 1.96^2 \cdot 0.25/10^{-4} = 3.8416 \cdot 2500 = 9604$. النتيجة: نحو 9600 عيّنة. الربط بالذكاء الاصطناعي: تحديد حجم مجموعة التحقّق قبل تقييم النموذج (لا «نجرّب حتى يثبت»).

مثال (6-4.29): تقدير معدّل الأُسّي المعطيات: $n = 100$، $\lambda = 2$ (متوسط العمر 0.5). المطلوب: حدّ التباين. الحل: الخطوة 1: $I_1 = 1/\lambda^2 = 0.25$؛ $I_n = 25$. الخطوة 2: $\text{sd} \ge 0.2 \Rightarrow \text{Var} \ge 0.04$ (10% من λ). النتيجة: الحساب بحدّ فيشر مباشر. الربط بالذكاء الاصطناعي: زمن between-failures في أنظمة موثوقية — دقّة تقدير MTBF.

مثال (7-4.29): حدود لا تُبلغ في العيّنات المنتهية المعطيات: برنولي بـ $p = 0.05$، $n = 20$. المطلوب: هل يبلغ مقدّرٌ ما الحدّ؟ الحل: الخطوة 1: الحدّ $p(1-p)/n = 0.0475/20 = 0.002375$. الخطوة 2: المقدّرون غير المتحيّزين في هذه العائلة (التي ليست أُسّية بمعلمتها الطبيعية مع إحصاء كافٍ خطّي) لا يبلغونه. النتيجة: الحدّ **أدنى** وليس بالضرورة ممكناً. الربط بالذكاء الاصطناعي: لا تعتمد على الحدود النظرية في تقييم نماذج صغيرة البيانات.

مثال (8-4.29): المنتظم $(0, \theta)$ — سقوط المتراجحة المعطيات: $\theta = 10$، $n = 100$. المطلوب: مقارنة تباين MLE بحدّ «فيشر». الحل: الخطوة 1: $I_1 = 1/\theta^2 = 0.01 \Rightarrow$ حدّ فيشر الصوري $1/(nI_1) = \theta^2/n = 1$. الخطوة 2: $\hat\theta = \max X_i$ بتباين $\theta^2/n^2 = 0.01 \approx$. النتيجة: المقدّر **أفضل بـ 100 مرّة** من الحدّ الصوري — لأنّ شروط الانتظام ساقطة. الربط بالذكاء الاصطناعي: تحذير: حدود فيشر تفترض دعامة ثابتة؛ احذر النماذج المقطوعة (truncated).

مثال (9-4.29): الصيغة المصفوفية المعطيات: $\mathcal{N}(\mu, \Sigma)$ في $\mathbb{R}^2$، $\Sigma = \begin{pmatrix} 4 & 1 \\ 1 & 1 \end{pmatrix}$، $n = 50$. المطلوب: حدّ تغاير $\hat\mu$. الحل: الخطوة 1: $I_1 = \Sigma^{-1}$؛ $I_n = 50\Sigma^{-1}$. الخطوة 2: $\text{Cov}(\hat\mu) \succeq \Sigma/50 = \begin{pmatrix} 0.08 & 0.02 \\ 0.02 & 0.02 \end{pmatrix}$. النتيجة: الحدّ مصفوفة — يقيّد **كلّ** تراكيب خطّية للمعلمات. الربط بالذكاء الاصطناعي: فترات ثقة مشتركة لمتّجه الأوزان، لا لكلّ وزن وحده.

مثال (10-4.29): المقدّرات المتحيّزة تكسر الحدّ — انحدار الحيد (ridge) المعطيات: $\hat\theta_{\text{ridge}} = (X^\top X + \lambda I)^{-1} X^\top y$، $\lambda > 0$. المطلوب: هل ينطبق حدّ كرامير–راو؟ الحل: الخطوة 1: المقدّر متحيّز $\Rightarrow$ (7.29) لا ينطبق؛ نستخدم (8.29) مع $b'(\theta) < 0$. الخطوة 2: البسط $(1 + b')^2 < 1 \Rightarrow$ الحدّ **أصغر** من حالة عدم التحيز. النتيجة: يمكن لمقدّر متحيّز أن يتفوّق على كلّ مقدّر غير متحيّز (ظاهرة شتاين). الربط بالذكاء الاصطناعي: التنظيم ليس «تخلياً عن الدقّة» بل استغلالٌ لتحيّز–تباين مثبت نظرياً.

مثال (11-4.29): أثر حجم الدفعة في تعلّم الآلة المعطيات: تدرّجٌ من دفعة بحجم B مقابل العيّنة كاملة (N). المطلوب: أثر ذلك على «معلومة» الخطوة. الحل: الخطوة 1: معلومة الدفعة $I_B = BI_1$ مقابل $I_N = NI_1$. الخطوة 2: نسبة التباين $I_N/I_B = N/B$. النتيجة: مضاعفة حجم الدفعة تقلّل تباين التقدير بنسبة 2 (قاعدة $\sqrt{\cdot}$ في معدّل التعلّم). الربط بالذكاء الاصطناعي: التفسير المعلوماتي لقاعدة التوسّع الخطّي لمعدّل التعلّم مع حجم الدفعة.

مثال (12-4.29): فترات ثقة لمعاملات الانحدار اللوجستي المعطيات: $\hat\beta_1 = 0.8$، معلومة العيّنة $I_n = 400$ لهذا المعامل. المطلوب: فترة ثقة 95%. الحل: الخطوة 1: $\text{sd} = \sqrt{1/400} = 0.05$. الخطوة 2: $0.8 \pm 1.96(0.05) = [0.702, 0.898]$. النتيجة: نسبة الأرجحية $e^{0.8} \approx 2.23$ بفترة $[2.02, 2.45]$. الربط بالذكاء الاصطناعي: مخرجات جداول المعاملات الإحصائية مبنيّة على هذه الحسابات.

مثال (13-4.29): دمج حسّاسين (Sensor fusion) المعطيات: حسّاسان مستقلان بـ $\sigma_1 = 1$ و $\sigma_2 = 2$ لقياس نفس الكمّية. المطلوب: أفضل تباين ممكن بعد الدمج. الحل: الخطوة 1: المعلومات تُجمع: $I = I_1 + I_2 = 1 + 1/4 = 1.25$. الخطوة 2: $\text{sd} \ge 1/1.25 = 0.8 \Rightarrow \text{Var} \ge 0.894$. النتيجة: أفضل من الحسّاس الأول (1.0) والثاني (2.0) معاً. الربط بالذكاء الاصطناعي: الدمج البايزي متعدّم الوسائط = جمع معلومات فيشر (قارن الفصل 16).

مثال (14-4.29): تصميم التجارب Optimal) (design المعطيات: انحدار خطّي، متر $I(\beta) = X^\top X/\sigma^2$.
المطلوب: معيار اختيار نقاط التجربة. الحل: الخطوة 1: A-optimality: صغّر $\mathrm{tr}(I^{-1})$ (متوسط التباين). الخطوة 2: D-optimality: صغّر $\det(I^{-1}) = \det I$ كبّر (حجم كرة الثقة). الخطوة 3: E-optimality: كبّر أصغر قيمة ذاتية لـ I. النتيجة: كلّها مسائل تحسين على متر المعلومة. الربط بالذكاء الاصطناعي: التعلّم النشط active) (learning = تعظيم معلومة فيشر للنقاط الموسومة.
مثال (15-4.29): متلازمة دي بروين — فيشر والإنتروبيا المعطيات: X متغيّر عشوائي و $Z \sim \mathcal{N}(0,1)$ مستقل، $X_t = X + \sqrt{t}\,Z$. المطلوب: معدّل نمو الإنتروبيا التفاضلية. الحل: الخطوة 1: متلازمة دي بروين: $\frac{d}{dt}h(X_t) = \frac{1}{2}J(X_t)$ حيث J معلومة فيشر لعائلة الموضع. الخطوة 2: للغاوسي $J = 1/\sigma^2 \Rightarrow \frac{d}{dt}\left[\frac{1}{2}\log(2\pi e(\sigma^2+t))\right] = \frac{1}{2(\sigma^2+t)}$ ✓. النتيجة: فيشر = «معدّل تدفّق الإنتروبيا» تحت قناة غاوسية مضافة.
الربط بالذكاء الاصطناعي: يربط هذا الفصل بالفصل 26، ويقع في قلب إثباتات متراجحة الإنتروبيا Power) (Entropy Inequality المستخدمة في حدود التعميم.

أخطاء شائعة

- تطبيق (7.29) على مقدّر متحيّز (يجب استخدام 8.29).
- تطبيقها خارج شروط الانتظام (الدعامة المتغيّرة).
- تفسير الحدّ على أنّه قابل للبلوغ دائماً (ليس كذلك في العيّنات المنتهية).
- نسيان عامل n: الحدّ يصغر بـ $1/n$ لا بـ $1/\sqrt{n}$ للتباين (الانحراف المعياري يصغر بـ $1/\sqrt{n}$).
- الخلط بين كفاءة المقدّر وكفاءة الخوارزمية العددية.

المبرهنة: اتجاه الانحدار الأشدّ لدالة الهدف $L(\theta)$ مقيساً في متر المعلومة، تحت قيد موضعي على تغيّر التوزيع، هو

$$\tilde{\nabla}_\theta L = I(\theta)^{-1}\nabla_\theta L \tag{9.29}$$

$$\theta_{t+1} = \theta_t - \eta\, I(\theta_t)^{-1}\nabla_\theta L(\theta_t) \tag{10.29}$$

ويُسمّى **التدرّج الطبيعي** natural) (gradient وهو يتحقق بحلّ مسألة منطقة الثقة الموضعية

$$\min_{d}\ \nabla L^\top d \quad \text{s.t.} \quad \frac{1}{2}d^\top I(\theta)d \le \varepsilon \tag{11.29}$$

التي حلّها $d^\star = -\sqrt{\dfrac{2\varepsilon}{\nabla L^\top I^{-1}\nabla L}}\; I^{-1}\nabla L$. وفي العائلة الأُسّية،

$$\tilde{\nabla}_\theta L = \nabla_\mu L \tag{12.29}$$

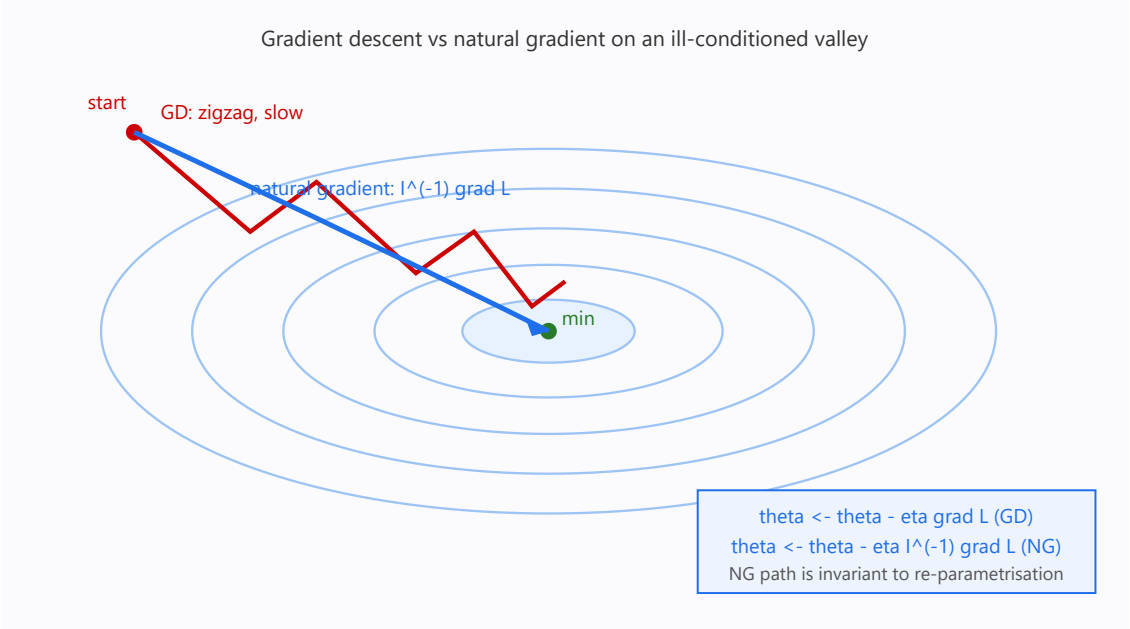
أي أنّ التدرّج الطبيعي في الإحداثيات الطبيعية θ يساوي التدرّج العادي في إحداثيات التوقّع μ.

جدول الرموز

الرمز	المعنى	ملاحظة
$\tilde{\nabla}$	التدرّج الطبيعي	وحّدته تختلف عن ∇
ε	نصف قطر منطقة الثقة بوحدة KL	بالnats
η	معدّل الخطوة	بلا أبعاد في فضاء المعلومة
I^{-1}	معكوس متر فيشر (أو شبه معكوس)	عملياً يُخمَّد
λ	معامل التخميد (damping)	$(I+\lambda I_d)^{-1}$
ثبات إعادة المُعلْمة	مسار NG لا يتغيّر بتبديل الإحداثيات	ميزته الكبرى

الرسم

<figure> الشكل<figcaption> 4.29: في وادٍ سيّئ الشرط يتعرّج التدرّج العادي، بينما يسلك التدرّج الطبيعي



شكل ٤.٢٩: *
التدرج الطبيعي مقابل التدرج العادي

$I^{-1}\nabla L$ طريقاً مباشراً، ومساره محصّن ضدّ إعادة المُعلْمة.<figcaption/> </figure>

البرهان

الخطوة 1 (الاشتقاق من منطقة الثقة): تريد أصغر $L(\theta+d) \approx L + \nabla L^\top d$ في كرة متر المعلومة $\frac{1}{2}d^\top I d \le \varepsilon$. دالة لاغرانج $\mathcal{L} = \nabla L^\top d + \lambda(\frac{1}{2}d^\top I d - \varepsilon)$. وبإدخال القيد بنشاط: $d = -\frac{1}{\lambda} I^{-1}\nabla L \Rightarrow \lambda = \sqrt{\nabla L^\top I^{-1}\nabla L / (2\varepsilon)}$ ■ الصيغة أعلاه.

الخطوة 2 (أشدّ انحدار): الانحدار الأشدّ في متر I هو $\arg\min_{\|d\|_I=1} \nabla L^\top d = -I^{-1}\nabla L / \|I^{-1}\nabla L\|_I$ بنفس الحساب. ■

الخطوة 3 (الثبات): بـ (3.29) مع $J = \partial\theta/\partial\phi$: $\tilde{\nabla}_\phi L = J^\top I(\theta)^{-1} J\, J^{-1}\nabla_\theta L = J^{-1}\tilde{\nabla}_\theta L$ — وهو بالضبط قانون تحوّل «متّجه» تحت تغيير الإحداثيات، أي أنّ التحديث الموضوعي (النقطة على المتشعّب) واحد، بخلاف التدرّج العادي الذي يتغيّر مساره. ■

الخطوة 4 (العائلة الأُسّية): من 14-2.29، $\partial\mu/\partial\theta = I$، فبقاعدة السلسلة $\nabla_\theta L = I\,\nabla_\mu L \Rightarrow I^{-1}\nabla_\theta L = \nabla_\mu L$، وهو (12.29). ■

خمسة عشر مثالاً محلولاً

مثال (29.5-1): برنولي — معكوس المتر يخفّف التشبّع المعطيات: $p = 0.9$، تدرّج الخسارة $g = 1$. المطلوب: التدرّج الطبيعي. الحل: الخطوة 1: $I = 1/(p(1-p)) = 1/0.09 = 11.111 \Rightarrow I^{-1} = 0.09$. الخطوة 2: $\tilde{g} = 0.09 \times 1 = 0.09$. النتيجة: خطوة أصغر بـ 11 مرّة من التدرّج العادي في الاتجاه نفسه. الربط بالذكاء الاصطناعي: التدرّج الطبيعي يكبح تلقائيّاً الاتجاهات الواثقة — حماية من «الانهيار الواثق».

مثال (29.5-2): بواسون بالرابط الكنسي المعطيات: $\lambda = 3$، $\phi = \log\lambda$، $g = 2$. المطلوب: $\tilde{g}$. الحل: الخطوة 1: $I(\phi) = \lambda = 3 \Rightarrow I^{-1} = 1/3$. الخطوة 2: $\tilde{g} = 2/3 \approx 0.667$. النتيجة: المتر في هذه الإحداثيات = المتوقّع ⇒ الخطوة تتناسب مع مقياس العدّ. الربط بالذكاء الاصطناعي: تطبيعٌ تلقائي بمقياس كلّ عدّاد (نقرات، طلبات، أحداث).

مثال (29.5-3): غاوسي بتباين معلوم المعطيات: $\sigma = 2$، $g = 1$. المطلوب: $\tilde{g}$. الحل: الخطوة 1: $I = 1/\sigma^2 = 0.25 \Rightarrow I^{-1} = \sigma^2 = 4$. الخطوة 2: $\tilde{g} = 4$. النتيجة: خطوة أكبر بـ 4 مرّات — مسموح لأنّ الضجيج كبير. الربط بالذكاء الاصطناعي: «عدم اليقين يضخّم الخطوة»: عكسُ الحدس لكنّه صحيح هندسيّاً.

مثال (29.5-4): الغاوسي بمعلمتين المعطيات: $\sigma = 3$، $g = (1, 1)$. المطلوب: التدرّج الطبيعي. الحل: الخطوة 1: $I = \mathrm{diag}(1/9,\ 2/9) \Rightarrow I^{-1} = \mathrm{diag}(9,\ 4.5)$. الخطوة 2: $\tilde{g} = (9,\ 4.5)$. النتيجة: المتوسط يتحرّك ضعفَ ما يتحرّك الانحراف المعياري نسبيّاً. الربط بالذكاء الاصطناعي: تفسير توزيع جهود التحديث بين المتوسط والتباين في النماذج الاحتمالية.

مثال (29.5-5): ثبات إعادة المعْلمة — الفرق الجوهري المعطيات: أعد المعْلمة $\theta = 10\phi$، $I(\theta) = 1$. المطلوب: مقارنة مساري GD و NG في الإحداثيتين. الحل: الخطوة 1: في θ: $\nabla_\theta L = 1 \Rightarrow$ GD يخطو -0.1. الخطوة 2: في ϕ: $\nabla_\phi L = 10 \Rightarrow$ GD يخطو $-0.1 \Rightarrow \Delta\phi = -0.1 \Rightarrow \Delta\theta = -1$ (عشرة أضعاف!). الخطوة 3: NG في θ: $\tilde{g} = 1 \Rightarrow \Delta\theta = -0.1$؛ وفي ϕ: $I(\phi) = 100$، $\tilde{g} = 10/100 = 0.1 \Rightarrow \Delta\phi = -0.01$ ✓ $\Delta\theta = -0.1$. النتيجة: NG يعطي نفس النقطة الجديدة، GD يعطي نقاطاً مختلفة تماماً. الربط بالذكاء الاصطناعي: هذا هو المعنى الدقيق لقولنا إنّ التدرّج الطبيعي «لا يعتمد على المعْلمة».

مثال (29.5-6): الانحدار اللوجستي — NG = نيوتن = IRLS المعطيات: نموذج $p(y|x) = \sigma(x^\top\beta)$، تصميم X. المطلوب: خطوة التدرّج الطبيعي. الحل: الخطوة 1: $I(\beta) = X^\top W X$ مع $W = \mathrm{diag}(s_i(1-s_i))$. الخطوة 2: $\nabla_\beta L = -X^\top(y-s)$. الخطوة 3: $\tilde{\nabla} = (X^\top W X)^{-1} X^\top(y-s)$ — وهي **بالضبط** خطوة نيوتن/IRLS.

النتيجة: في العائلات الأُسّية بالرابط الكنسي يتطابق التدرّج الطبيعي مع نيوتن. الربط بالذكاء الاصطناعي: يفسّر لماذا تعمل مكتبات GLM بخوارزمية واحدة لكلّ العائلات الأُسّية.

مثال (29.5-7): وادٍ سيّئ الشرط المعطيات: $I = \mathrm{diag}(100,\ 1)$، $\nabla L = (2,\ 2)$. المطلوب: اتجاها GD و NG. الحل: الخطوة 1: GD: $(-2, -2) \Rightarrow$ زاوية $45°$ (يتعرّج في الوادي). الخطوة 2: NG: $d_{\mathrm{NG}} = -(2/100,\ 2/1) = (-0.02, -2)$. الخطوة 3: نسبة المكوّنين: 1:100 بدلاً من 1:1. النتيجة: NG يضخّم الاتجاه «المسطّح» (قليل المعلومة) 100 مرّة. الربط بالذكاء الاصطناعي: هذا بالضبط أثر Momentum/Adam المطلوب، لكن باشتقاق هندسي صريح.

مثال (29.5-8): حلّ منطقة الثقة بالأرقام المعطيات: $I = \mathrm{diag}(4, 1)$، $\nabla L = (2, 2)$، $\varepsilon = 0.5$ nats. المطلوب: خطوة التدرّج الطبيعي المشدّدة والتحقّق من القيد. الحل: الخطوة 1: $I^{-1}\nabla L = (0.5,\ 2)$؛ $\nabla^\top I^{-1}\nabla = 2(0.5) + 2(2) = 1 + 4 = 5$. الخطوة 2: المعامل $\sqrt{2\varepsilon/5} = \sqrt{1/5} = 0.4472$. الخطوة 3: $d = (-0.2236, -0.8944)$. الخطوة 4: تحقّق: $\frac{1}{2}(0.2 + 0.8) = 0.5 = \frac{1}{2}(4 \times 0.05 + 1 \times 0.8)$ ✓. النتيجة: الخطوة تحترم القيد بالضبط وتتّجه وفق التدرّج الطبيعي. الربط بالذكاء الاصطناعي: هذه هي خطوة التدرّج الطبيعي المقترنة

بمنطقة ثقة في TRPO و NPG.

مثال (29.5-9): فيشر الحقيقي أم التجريبي في NG؟ المعطيات: شبكة مصنّفة في منتصف التدريب، دقّة 70%. المطلوب: أيّ متر نعكس؟ الحل: الخطوة 1: التجريبي يستخدم التسميات $y_n \Rightarrow$ «متر ما يفاجئ النموذج في البيانات». الخطوة 2: الحقيقي يستخدم $y \sim p_\theta \Rightarrow$ «متر ما يغيّر تنبؤات النموذج فعلاً». الخطوة 3: عند خطأ 30% يختلف الاثنان جوهرياً؛ الأوّل قد يقترح خطوات لا تغيّر سلوك النموذج. النتيجة: للتدرّج الطبيعي الصحيح استخدم الحقيقي (أو توزيع النموذج). الربط بالذكاء الاصطناعي: يفسّر تفوّق K-FAC على الطرق المعتمدة على التسميات وحدها.

مثال (29.5-10): التخميد الضروري المعطيات: متر شاذّ I بأصغر قيمة ذاتية 10^{-6} وأكبرها 10^{2}. المطلوب: أثر معكوس المتر وكيفية العلاج. الحل: الخطوة 1: معكوس القيم: 10^{6} و $10^{-2} \Rightarrow$ خطوة منفجرة في اتجاه واحد. الخطوة 2: التخميد: $(I+\lambda I_d)^{-1}$ بـ $\lambda = 0.1$ يعطي قيماً ≈ 10 و ≈ 9.9. النتيجة: التخميد يحدّد الاتجاهات «غير المعرَّفة» (التي لا تؤثّر في التوزيع). الربط بالذكاء الاصطناعي: كلّ تطبيقات NG العمليّة (K-FAC، TRPO، EWC) تستخدم تخميداً إلزامياً.

مثال (29.5-11): K-FAC — اقتصاد الحساب المعطيات: طبقة كاملة الاتصال $256 \to 784$. المطلوب: تكلفة تخزين وعكس المتر كاملاً مقابل تقريب كرونيكر. الحل: الخطوة 1: عدد الأوزان $mn = 200{,}704 \Rightarrow$ المتر الكامل $(mn)^2 \approx 4.0 \times 10^{10}$ عنصراً (غير ممكن). الخطوة 2: التقريب $I \approx A \otimes G$ بـ $A = \mathbb{E}[aa^\top]$ (784^2) و $G = \mathbb{E}[gg^\top]$ (256^2). الخطوة 3: $784^2 + 256^2 = 680{,}192$ عنصراً $\Rightarrow$ توفير بنحو 5.9×10^4 مرّة. الخطوة 4: العكس: $(A \otimes G)^{-1} = A^{-1} \otimes G^{-1} \Rightarrow$ تكلفة $784^3 + 256^3 \approx 5.0 \times 10^8$ بدل $(mn)^3 \approx 8 \times 10^{15}$. النتيجة: K-FAC يجعل التدرّج الطبيعي ممكناً على الشبكات الكبيرة. الربط بالذكاء الاصطناعي: أهمّ تطبيق عملي للهندسة المعلوماتية في التعلّم العميق.

مثال (29.5-12): هل Adam تدرّجٌ طبيعي؟ المعطيات: مُحسِّن Adam بمتوسط متحرّك لتدرّجات الدفعة. المطلوب: العلاقة بالتدرّج الطبيعي. الحل: الخطوة 1: Adam يقيس $\mathbb{E}[g_i^2]$ — وهو **قطر** متر فيشر التجريبي للمخرجات الغاوسية/الأُسّية. الخطوة 2: NG يستخدم I كاملاً (مع المكوّنات المختلطة) تحت توزيع النموذج. النتيجة: Adam $\approx$ تدرّج طبيعي **قطري وتجريبي**؛ يفتقد الارتباطات بين المعلمات. الربط بالذكاء الاصطناعي: يفسّر نجاح Adam في الممارسة وفشله أحياناً حيث تفيد الارتباطات (قارن الفصل 23).

مثال (29.5-13): التدرّج الطبيعي لطبقة السوفتماكس المعطيات: K أصناف، احتمالات s، تسمية واحد ساخن y، تدرّج $v = s - y$. المطلوب: $\tilde\nabla$ بالمعكوس الشبه عام. الحل: الخطوة 1: $I = \mathrm{diag}(s) - ss^\top$ شاذّ (رتبة $K-1$) $\Rightarrow$ استخدم I^+ على فضاء $\sum u_i = 0$. الخطوة 2: بحلّ $(\mathrm{diag}(s) - ss^\top)u = v$ مع $1^\top u = 0$: $u_i = \frac{v_i}{s_i} - \frac{1}{K}\sum_j \frac{v_j}{s_j}$. الخطوة 3: $(K=2)$: $s = (0.8, 0.2)$، $y = (1,0) \Rightarrow v = (-0.2, 0.2) \Rightarrow v/s = (-0.25, 1) \Rightarrow$ المتوسط $0.375 \Rightarrow u = (-0.625, 0.625)$. النتيجة: التدرّج الطبيعي يضخّم تحديث الأصناف ذات الاحتمال الصغير بمعامل $1/s_i$. الربط بالذكاء الاصطناعي: لهذا تُخمَّد هذه الخطوة عملياً وإلا انفجر التحديث للأصناف النادرة.

مثال (29.5-14): التدرّج الطبيعي للسياسة (NPG/TRPO) المعطيات: هدف RL بمكافأة متوقّعة $\nabla J = \mathbb{E}[\nabla \log \pi(a|s)\, A(s,a)]$. المطلوب: خطوة NPG. الحل: الخطوة 1: متر السياسة $I = \mathbb{E}_{s,a}[\nabla \log \pi \, \nabla \log \pi^\top]$. الخطوة 2: $d_{\text{NPG}} = I^{-1}\nabla J$ بمقياس يخضع لقيد $\frac{1}{2} d^\top I d \le \delta$. الخطوة 3: القيد يعني $\mathbb{E}[D_{\text{KL}}(\pi_{\text{old}} \| \pi_\theta)] \le \delta$ بالتقريب الموضعي (29.4). النتيجة: خطوة تتجاهل إعادة معْلمة السياسة، وتكبح تغيير السلوك دفعة واحدة. الربط بالذكاء الاصطناعي: الأساس النظري لـ TRPO ثمّ PPO (تقريب بالقصّ).

مثال (15-5.29): التدرّج الطبيعي في الاستدلال المتغيّر (VI) المعطيات: عائلة تغيّرية q_λ بهدف ELBO. المطلوب: لماذا NG أفضل من GD في VI؟ الحل: الخطوة 1: الهدف في VI ليس إقليديّاً: اتجاهات λ المختلفة تغيّر q بمقادير معلوماتية مختلفة. الخطوة 2: NG خطوة في فضاء التوزيعات لا في فضاء الأرقام $\Rightarrow$ تحديثات مستقلّة عن المعْلمة. الخطوة 3: للغاوسي المتعدّد في الإحداثيات الطبيعية $(\Sigma^{-1}m,\ -\frac{1}{2}\Sigma^{-1})$ تصير الخطوة مغلقة الشكل. النتيجة: تقارب أسرع بمراتب في النماذج ذات الارتباطات القويّة بين المعلمات. الربط بالذكاء الاصطناعي: يستخدم في VI التلقائي (automatic dffierentiation (VI والأنظمة الاحتمالية الحديثة.

أخطاء شائعة

- عكس I بدون تخميد (انفجار في الاتجاهات الشاذّة).
- استخدام فيشر التجريبي بالتسميات حيث يلزم فيشر الحقيقي.
- الظنّ أنّ NG «أسرع دائماً»: تكلفة $O(d^3)$–$O(d^2)$ لكلّ خطوة قد لا تعوّضها الخطوات الأقلّ.
- نسيان أنّ (12.29) يخصّ العائلات الأُسّية بإحداثياتها الطبيعية لا أيّ معْلمة اعتباطية.
- الخلط بين منطقة ثقة في KL ومنطقة ثقة إقليدية: وحدات ε بالnats لا بوحدات المعلمة.

المبرهنة: للعائلة الأُسّية $p_\theta(x) = h(x)\exp(\theta^\top T(x) - \psi(\theta))$:

$$\mu \;=\; \mathbb{E}_{p_\theta}[T(X)] \;=\; \nabla\psi(\theta), \qquad \theta \;=\; \nabla\varphi(\mu), \qquad \varphi(\mu) = \theta^\top\mu - \psi(\theta) \tag{13.29}$$

$$I(\theta) \;=\; \nabla^2\psi(\theta), \qquad I(\mu)^{-1} \;=\; \nabla^2\varphi(\mu) \tag{14.29}$$

$$D_{\mathrm{KL}}(p_\theta \| p_{\theta'}) \;=\; D_\psi(\theta' \| \theta) \;=\; \psi(\theta') - \psi(\theta) - \nabla\psi(\theta)^\top(\theta' - \theta) \tag{15.29}$$

$$\Gamma^{(\alpha)}_{ijk} \;=\; \mathbb{E}\big[\partial_i\partial_j\ell\;\partial_k\ell\big] \;+\; \frac{1-\alpha}{2}\,\mathbb{E}\big[\partial_i\ell\,\partial_j\ell\,\partial_k\ell\big] \tag{16.29}$$

مع $\Gamma^{(1)} = \Gamma^{(e)} = 0$ (العائلة **مستوية e**) و $\Gamma^{(-1)} = \Gamma^{(m)} = \partial^3\psi$ (العائلة **مستوية m** في إحداثيات μ)، و $\Gamma^{(0)} = \frac{1}{2}\partial^3\psi$ هو اتصال ليفى-تشيفيتا. وتباعد KL يخضع لمتراجحة فيثاغورس المعمّمة:

$$D(q\|p) \;=\; D(q\|\hat{p}) \;+\; D(\hat{p}\|p) \qquad \forall p \in M \text{ مستوٍ e} \tag{17.29}$$

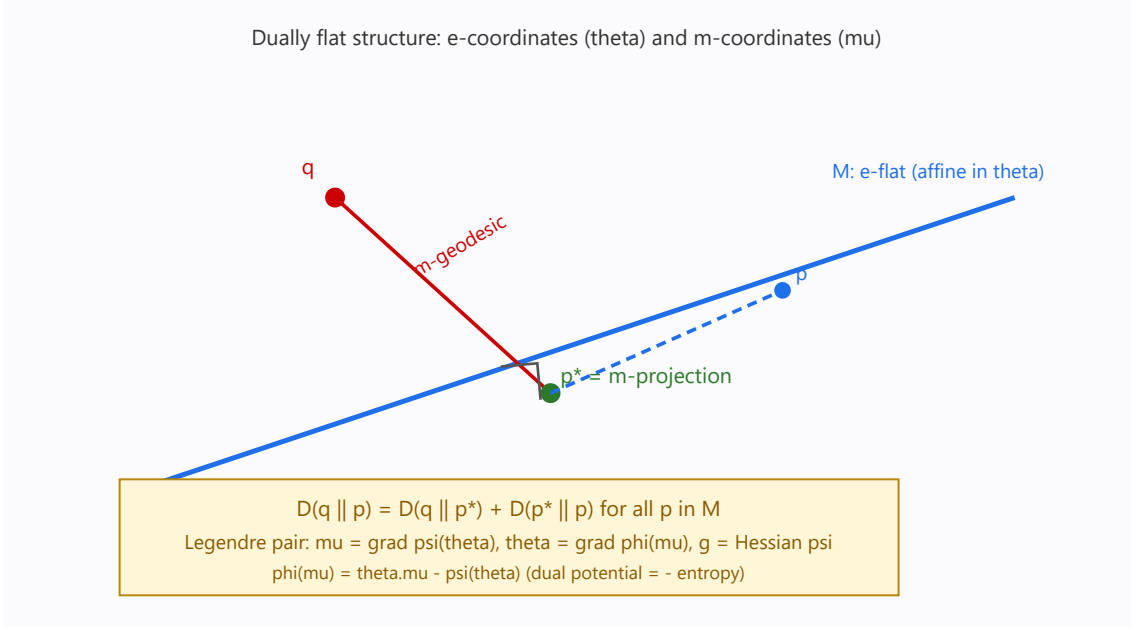
حيث $\hat{p}$ هو **الإسقاط m** لـ q على M.

جدول الرموز

الرمز	المعنى	ملاحظة
θ	إحداثيات طبيعية (e-coordinates)	معاملات العائلة الأُسّية
μ	إحداثيات توقّعية (m-coordinates)	$\mathbb{E}[T]$
$T(x)$	الإحصاء الكافي	
ψ	لوغاريتم القاسم (cumulant)	محدّب
φ	الكمون المزدوج	$-$ =الإنتروبيا للعائلة الأُسّية
D_ψ	تباعد بريغمان	لاتماثل، يعمّم مربع المسافة
$\Gamma^{(\alpha)}$	اتصال α	$\alpha=1$ تعلّق e، -1 تعلّق m، 0 ريماني
مستوٍ e/m	استواء مزدوج	أساس «الاستواء المزدوج» للأمارِي

الرسم

<figure> الشكل<figcaption> 5.29: الإسقاط m على متشعّب مستوٍ e يقابل زاوية قائمة معلوماتية، فينشأ تطابق



شكل ٥.٢٩: *
البنية المزدوجة وإسقاطات فيثاغورس

فيثاغورس (17.29).</figcaption> </figure>

البرهان (مخطّط)

الخطوة 1 (شرعية Legendre): ψ محدّبة لأنّ $\nabla^2\psi = I \succeq 0$ (من 14-2.29)؛ و$\nabla\psi$ رتيبة $\Rightarrow$ تحويل ليجاندر صالح، و$\nabla\varphi = (\nabla\psi)^{-1}$.

الخطوة 2 (المتر المزدوج): بـ $\theta = \nabla\varphi(\mu)$: $\frac{\partial\mu}{\partial\theta} = \nabla^2\psi = I$ و $\frac{\partial\theta}{\partial\mu} = \nabla^2\varphi = I^{-1}$ $\Rightarrow$ (14.29).

الخطوة 3 (KL تباعد بريغمان):

$$D_{\mathrm{KL}}(p_\theta \| p_{\theta'}) = \mathbb{E}_\theta[(\theta-\theta')^\top T - \psi(\theta) + \psi(\theta')] = (\theta-\theta')^\top \nabla\psi(\theta) - \psi(\theta) + \psi(\theta')$$

وهو بعينه $D_\psi(\theta' \| \theta)$ بتعريف بريغمان (لاحظ انقلاب الرتبة). ■

الخطوة 4 (فيثاغورس): D_ψ تحقّق متطابقة ثلاثيّة: $D_\psi(a\|c) = D_\psi(a\|b) + D_\psi(b\|c) + \langle a-b, \nabla\psi(b) - \nabla\psi(c)\rangle$. إذا كانت M مستوية في θ والجيوديسية m من q إلى $\hat{p}$ متعامدة على M، فإنّ الحدّ الأخير يصفُر $\Rightarrow$ (17.29). ■

الخطوة 5 (الاتصالات): بحساب $\partial_k g_{ij} = \mathbb{E}[\partial_k\partial_i\ell\,\partial_j\ell] + \mathbb{E}[\partial_i\ell\,\partial_k\partial_j\ell] + \mathbb{E}[\partial_i\ell\,\partial_j\ell\,\partial_k\ell]$ وتعريف $\Gamma^{(\alpha)}_{ijk} = \frac{1}{2}(\partial_i g_{jk} + \partial_j g_{ik} - \partial_k g_{ij}) + \frac{\alpha}{2}\mathbb{E}[\partial_i\ell\partial_j\ell\partial_k\ell]$ بالصيغة المكافئة $\Rightarrow$ (16.29). وفي العائلة الأُسّية $\partial_i\partial_j\ell = -\partial_i\partial_j\psi$ ثابت $\Rightarrow \mathbb{E}[\partial_i\partial_j\ell\,\partial_k\ell] = 0 \Rightarrow \Gamma^{(1)} = 0$ و $\Gamma^{(-1)} = \partial^3\psi$. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.29): برنولي في الإحداثيات الطبيعية المعطيات: $p \in (0,1)$. المطلوب: θ و ψ و μ. الحل: الخطوة 1: $p^x(1-p)^{1-x} = \exp\big(x\log\frac{p}{1-p} + \log(1-p)\big) \Rightarrow \theta = \log\frac{p}{1-p}$، $T(x) = x$. الخطوة 2: $\psi(\theta) = \log(1+e^\theta)$. الخطوة 3: $\mu = \psi'(\theta) = \frac{e^\theta}{1+e^\theta} = p$ ✓. النتيجة: الإحداثي الطبيعي هو اللوغيت، والإحداثي التوقّعي هو الاحتمال نفسه. الربط بالذكاء الاصطناعي: لوجِتات الشبكة قبل السيغمويد = إحداثيات e، مخرجاتها = إحداثيات m.

مثال (2-6.29): بواسون في الإحداثيات الطبيعية المعطيات: $p_\lambda(x) = e^{-\lambda}\lambda^x/x!$. المطلوب: θ, ψ, μ والمتر. الحل: الخطوة 1: $\frac{1}{x!}\exp(x\log\lambda - \lambda) = \Rightarrow \theta = \log\lambda$، $\psi(\theta) = e^\theta$. الخطوة 2: $\lambda = e^\theta = \psi' = \mu$؛ $I = \psi'' = e^\theta = \lambda$. النتيجة: المتر = المتوقّع في الإحداثيات الطبيعية (طابق 3-6.29). الربط بالذكاء الاصطناعي: تفسيرٌ موحّد لكون متر GLM ذي الرابط الكنسي = المتوسط المتوقّع.

مثال (3-6.29): الغاوسي بتباين معلوم المعطيات: $\mathcal{N}(\mu, \sigma^2)$ بـ σ^2 معلوم. المطلوب: الإحداثيات الطبيعية. الحل: الخطوة 1: $\times \exp\big(\frac{x\mu}{\sigma^2} - \frac{\mu^2}{2\sigma^2}\big)$ ثوابت $\Rightarrow \theta = \mu/\sigma^2$، $T(x) = x$. الخطوة 2: $\psi(\theta) = \theta^2\sigma^2/2$. الخطوة 3: $\mu_{\text{coord}} = \psi' = \theta\sigma^2$ ✓، و $I = \psi'' = \sigma^2$ (في إحداثيات θ). النتيجة: المتر في الإحداثيات الطبيعية σ^2 (وليس $1/\sigma^2$ — تذكّر الإحداثيات!). الربط بالذكاء الاصطناعي: تحذير عملي: قيمة I بلا تحديد الإحداثيات لا معنى لها.

مثال (4-6.29): الكمون المزدوج هو سالب الإنتروبيا المعطيات: برنولي في إحداثيات $p = \mu$. المطلوب: $\varphi(\mu)$. الحل: الخطوة 1: $\theta\mu - \psi(\theta) = \varphi$ مع $\theta = \log\frac{\mu}{1-\mu}$ و $\psi = -\log(1-\mu)$. الخطوة 2: $\mu\log\mu + (1-\mu)\log(1-\mu) = \mu\log\frac{\mu}{1-\mu} + \log(1-\mu) = \varphi$. الخطوة 3: $\varphi = -H(\mu)$ حيث H إنتروبيا برنولي (الفصل 26) ✓. النتيجة: $\nabla\varphi = \theta$ و $\nabla^2\varphi = 1/(\mu(1-\mu)) = I(\mu)^{-1}$ ✓. الربط بالذكاء الاصطناعي: يربط الهندسة المعلوماتية بالإنتروبيا ربطاً مباشراً: الإنتروبيا هي الكمون المزدوج.

مثال (5-6.29): تباعد KL بوصفه بريغمان — تحقّق عددي المعطيات: برنولي $p = 0.3$ و $p' = 0.7$. المطلوب: KL بالصيغتين. الحل: الخطوة 1: مباشرةً $D = 0.3\ln\frac{0.3}{0.7} + 0.7\ln\frac{0.7}{0.3} = -0.2546 + 0.5935 = 0.3389$ nats. الخطوة 2: $\theta = \ln(3/7) = -0.8473$، $\theta' = \ln(7/3) = 0.8473$؛ $\psi(\theta) = \ln(1+e^\theta)$: $\psi(-0.8473) = \ln(1.4286) = 0.3567$، $\psi(0.8473) = \ln(3.3333) = 1.2040$. الخطوة 3: $D_\psi(\theta'\|\theta) = 1.2040 - 0.3567 - 0.3(0.8473+0.8473) = 0.8473 - 0.5084 = 0.3389$ ✓. النتيجة: تطابق تامّ؛ KL تباعد بريغمان بكمون ψ. الربط بالذكاء الاصطناعي: كلّ خصائص بريغمان (الحدبة، فيثاغورس) تُورَث عن KL مباشرةً.

مثال (6-6.29): فيثاغورس المعلوماتية المعطيات: q = توزيع تجريبي، M = عائلة غاوسية (مستوية، e) = $\hat{p}$ MLE. المطلوب: تفسير تفكيك (17.29). الحل: الخطوة 1: $\hat{p}$ يقلّل $D(q\|p)$ على $M \Rightarrow$ إسقاط m. الخطوة 2: لأيّ غاوسي آخر p: $D(q\|p) = D(q\|\hat{p}) + D(\hat{p}\|p) \geq D(q\|\hat{p})$. النتيجة: الأمثلية العالمية لإسقاط m نتيجة هندسية بحتة (زاوية قائمة). الربط بالذكاء الاصطناعي: يضمن عدم وجود «أمثليّة محلّية خفيّة» في خطوة M من EM للعائلات الأُسّية.

مثال (7-6.29): مطابقة العزوم = تقليل KL على عائلة أُسّية المعطيات: نريد تقريب توزيع تجريبي q بغاوسي $\mathcal{N}(m, s^2)$ بتقليل $D(q\|p)$. المطلوب: الحل. الحل: الخطوة 1: M مستوية، e والإسقاط m يعني مطابقة الإحصاء

الكافي $T(x) = (x, x^2)$. الخطوة 2: $m = \mathbb{E}_q[X]$، $s^2 = \mathrm{Var}_q(X)$. النتيجة: MLE الغاوسي = مطابقة العزوم تماماً (لا تكرار عدد مطلوب). الربط بالذكاء الاصطناعي: لماذا تُحلّ بعض خطوات M بشكل مغلق بينما تحتاج أخرى تكراراً.

مثال (29.6-8): KL الأمامي مقابل العكسي — أثر الوضع المعطيات: $q = 0.5\mathcal{N}(-2, 0.25) + 0.5\mathcal{N}(2, 0.25)$؛ نقترب بغاوسي واحد. المطلوب: حلّ $D(q\|p)$ مقابل $D(p\|q)$. الحل: الخطوة 1: $D(q\|p)$ (إسقاط :(m مطابقة العزوم $\Rightarrow \mu = 0$، $\sigma^2 = \mathrm{Var}(q) = 4 + 0.25 = 4.25 \Rightarrow \sigma \approx 2.06$ (يغطي النمطين). الخطوة 2: $D(p\|q)$ (إسقاط :(e يبحث عن نمط واحد $\Rightarrow \mu \approx \pm 2$، $\sigma^2 \approx 0.25$ (انهيار إلى نمط). النتيجة: KL الأمامي «شامل» (moment-seeking) والعكسي «متتبّع نمط» (mode-seeking). الربط بالذكاء الاصطناعي: هذا هو التفسير الهندسي لانهيار النمط في VAE ولتعدّد أنماط GAN.

مثال (29.6-9): متى يفشل فيثاغورس؟ المعطيات: M عائلة غير مستوية e (مثل خليط غاوسي بمعلمات الخلط متغيّرة). المطلوب: هل ينطبق (29.17)؟ الحل: الخطوة 1: شرط التطبيق: M مستوٍ في الإحداثيات المستخدمة e) أو m). الخطوة 2: عائلات الخلط ليست مستوية e ولا m $\Rightarrow$ الحدّ الثالث في البرهان لا يصفُر. النتيجة: لا تفكيك فيثاغورسي $\Rightarrow$ قد تظهر أمثليّات محلّية في تقريب الخلائط. الربط بالذكاء الاصطناعي: التفسير الهندسي لصعوبة تدريب خلائط الخبراء (MoE) مقابل النماذج الأُسّية.

مثال (29.6-10): الاتصالات الثلاثة الكبرى المعطيات: عائلة أُسّية عامّة. المطلوب: قيم $\Gamma^{(\alpha)}$ للقيم $\alpha = 1, 0, -1$. الحل: الخطوة 1: $\Gamma^{(1)} = 0 \Rightarrow$ الإحداثيات θ جيوديسية للاتصال e. الخطوة 2: $\partial^3\psi = \Gamma^{(-1)} \Rightarrow$ الإحداثيات μ جيوديسية للاتصال m. الخطوة 3: $\Gamma^{(0)} = \frac{1}{2}\partial^3\psi \Rightarrow$ اتصال ليفي-تشيفيتا (الجيوديسيات = أقصر طرق فيشر-راو). النتيجة: ثلاثة اتصالات في متشعّب واحد، الاستواء المزدوج يعني $\Gamma^{(1)}$ و $\Gamma^{(-1)}$ صفريْن كلٌّ في إحداثياته. الربط بالذكاء الاصطناعي: أساس خوارزميات «الانعكاس المزدوج» في تحسين التوزيعات (mirror descent).

مثال (29.6-11): تباعدات α المعطيات: تعريف تباعد α للأمارِي. المطلوب: الحالات الخاصّة. الحل: الخطوة 1: $D^{(\alpha)}(p\|q) = \frac{4}{1-\alpha^2}\left(1 - \int p^{(1-\alpha)/2} q^{(1+\alpha)/2} d\mu\right)$؛ و $\alpha \to -1$ يعطي $D_{\mathrm{KL}}(p\|q)$؛ و $\alpha \to +1$ يعطي $D_{\mathrm{KL}}(q\|p)$. الخطوة 3: $\alpha = 0$ يعطي $4(1 - \mathrm{BC})$ معامل بَهَتَّشاريا $\Rightarrow$ مرتبطاً بمسافة هيلينغر. الخطوة 4: $\alpha = 3$ يعطي تباعد χ^2 (بيرسون). النتيجة: عائلةٌ واحدة مستمرّة تجمع تباعدات الفصل 27 تحت سقف هندسي. الربط بالذكاء الاصطناعي: اختيار α في خسائر التدريب = اختيار سلوك النمط (شامل/متتبّع).

مثال (29.6-12): الحقل المتوسط (mean-field) إسقاط m المعطيات: استدلال متغيّري يقيد $q(z) = \prod_j q_j(z_j)$. المطلوب: التفسير الهندسي. الحل: الخطوة 1: عائلة الحقول المنفصلة مستوية **m** في إحداثيات العزوم. الخطوة 2: تقليل $D(q\|p) \Rightarrow$ إسقاط m $\Rightarrow$ يخضع لفيثاغورس. النتيجة: الحقل المتوسط إسقاط متعامد معلوماتياً لا تقريب اعتباطي. الربط بالذكاء الاصطناعي: يفسّر استقرار تحديثات CAVI وصعود ELBO الرتيب.

مثال (29.6-13): التدرّج الطبيعي = تدرّج عادي في إحداثيات m المعطيات: عائلة أُسّية، $\nabla_\mu L = g$. المطلوب: التدرّج الطبيعي في θ. الحل: الخطوة 1: $\frac{\partial\mu}{\partial\theta} = I \Rightarrow \nabla_\theta L = I\,\nabla_\mu L$. الخطوة 2: $\tilde{\nabla}_\theta L = I^{-1}\nabla_\theta L = \nabla_\mu L = g$. النتيجة: NG في الإحداثيات الطبيعية = GD في إحداثيات التوقّع (برهان 29.12). الربط بالذكاء الاصطناعي: خوارزمية «التحديث في فضاء التوقّع ثمّ العودة» أسهل تنفيذاً من عكس متر ضخم.

مثال (29.6-14): هبوط المرآة (mirror descent) بوصفه تدرّجاً طبيعياً المعطيات: تحديث هبوط المرآة بكمون ψ. المطلوب: العلاقة. الحل: الخطوة 1: $\nabla\psi(\theta_{t+1}) = \nabla\psi(\theta_t) - \eta\nabla L(\theta_t)$. الخطوة 2: هذا بالضبط تحديث التدرّج الطبيعي: $\mu_{t+1} = \mu_t - \eta\nabla_\mu L$ (بـ 29.6-13). النتيجة: هبوط المرآة بمرآة $\psi \equiv$ التدرّج الطبيعي على العائلة الأُسّية. الربط بالذكاء الاصطناعي: يوحّد طرق التحسين في الفصلين 23 و25 مع هندسة هذا الفصل.

مثال (15-6.29): انحناء متشعّب الشبكة العصبية المعطيات: $p_\theta(y|x)$ بشبكة عميقة. المطلوب: هل المتشعّب مستوٍ؟ الحل: الخطوة 1: العائلة ليست أُسّية (المعلمات تدخل لاخطّياً) $\Rightarrow \Gamma^{(1)} \neq 0$ عامّةً. الخطوة 2: في مناطق التشبّع يقترب $\partial^3\psi$ من قيم ضخمة $\Rightarrow$ انحناء عالٍ. النتيجة: لا استواء مزدوج $\Rightarrow$ لا تطابق فيثاغورسي $\Rightarrow$ صعوبة التحسين معقولة هندسيّاً. الربط بالذكاء الاصطناعي: تبريرٌ نظري لاستخدام تقريبات المتر (K-FAC) بدل المتر الدقيق وللاعتماد على مناطق الثقة.

أخطاء شائعة

- نسيان انقلاب الرتبة في (15.29): KL تباعد بريغمان بـ $D_\psi(\theta'\|\theta)$ لا العكس.
- تطبيق فيثاغورس (17.29) على متشعّب غير مستوٍ.
- ذكر قيمة عددية لـ «متر فيشر» دون تحديد الإحداثيات (قارن 3-6.29).
- الخلط بين إسقاط e وإسقاط m (الأوّل يقلّل $D(p\|q)$ والثاني $D(q\|p)$).
- افتراض أنّ كلّ خسارة «تشبه «KL هي تباعد بريغمان (الشرط: أن تكون العائلة أُسّية).

المبرهنة: ليكن $\mathcal{M}$ متشعّباً معلوماتياً متصلاً. عرّف

$$d_F(p,q) \;=\; \inf_{\gamma(0)=p,\,\gamma(1)=q} \int_0^1 \sqrt{\dot\gamma(t)^{\top} I(\gamma(t))\,\dot\gamma(t)}\; dt \tag{18.29}$$

فإنّ d_F **مترٌّ** (متماثل، يحقّق متراجحة المثلّث، $d_F = 0 \Leftrightarrow p = q$) — بخلاف KL — ويُسمّى **مسافة فيشر–راو** (أو مسافة راو). وهي المتر الريماني الوحيد (حتى ثابت ضرب) الثابت تحت الإحصاءات الكافية (**مبرهنة تشينتسوف**):

$$c \cdot I,\; c>0 \tag{19.29}$$ أيّ متر ريماني ثابت تحت تطبيقات ماركوف الإحصائية هو

وأمثلة مغلقة الشكل:

$$d_F(p,q) \;=\; 2\big|\arcsin\sqrt{p} - \arcsin\sqrt{q}\big| \;=\; 2\arccos\!\big(\sqrt{pq} + \sqrt{(1-p)(1-q)}\big) \;\le\; \pi \tag{20.29}$$ برنولي:

$$ds^2 = \frac{d\mu^2 + 2\,d\sigma^2}{\sigma^2}, \qquad d_F = \sqrt{2}\,\cosh^{-1}\!\left(\frac{(\mu_1-\mu_2)^2 + 2(\sigma_1^2+\sigma_2^2)}{4\sigma_1\sigma_2}\right) \tag{21.29}$$ غاوسي أحادي:

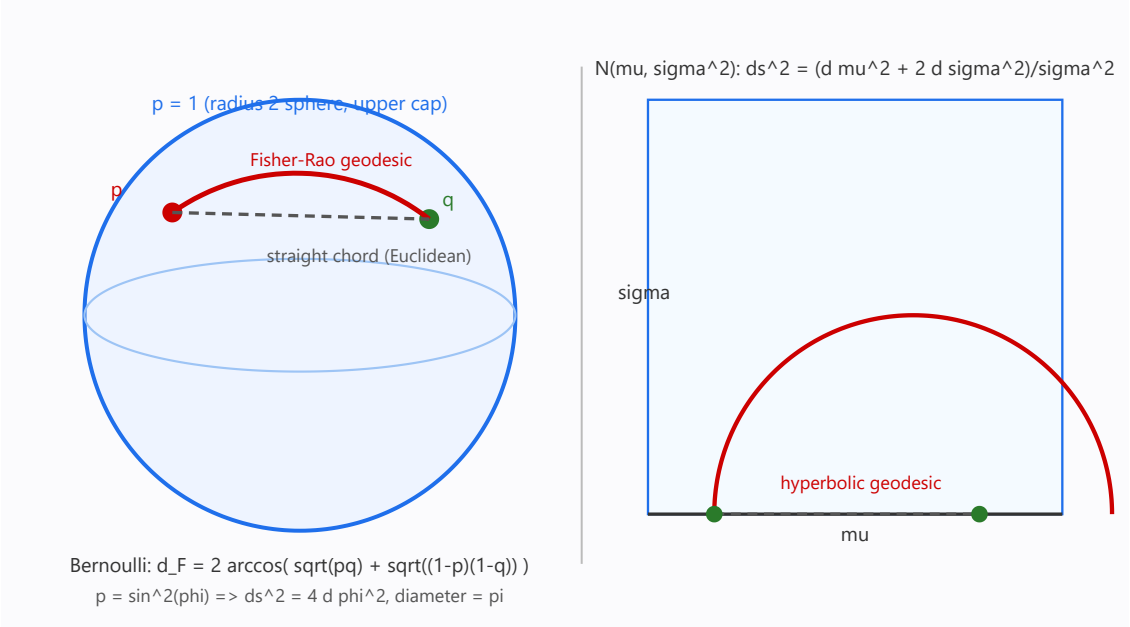
$$d_F(\mu_1,\mu_2) = \sqrt{(\mu_1-\mu_2)^{\top}\Sigma^{-1}(\mu_1-\mu_2)} \tag{22.29}$$ غاوسي متعدّد بـ ثابت:Σ

جدول الرموز

الرمز	المعنى	ملاحظة
γ	منحنى على المتشعّب	الجيوديسية تقلّل الطول
d_F	مسافة فيشر–راو	متر (بخلاف KL)
BC	معامل بَهَتَّشاريا $\sum_k \sqrt{p_k q_k}$	$d_F = 2\arccos(\mathrm{BC})$
$\cosh^{-1}$	جيب التمام الزائدي العكسي	هندسة زائدية
π	قطر متشعّب برنولي	أقصى بُعد ممكن
تشينتسوف	وحدانية المتر الثابت	1972 Čencov

الرسم

<figure> الشكل<figcaption> 6.29: يساراً: متشعّب برنولي = قبعة كرة نصف قطرها 2، والجيوديسية قوس دائرة كبرى لا وتر؛ يميناً: عائلة الغاوسي = نصف مستوي بوانكاريه بجيوديسيات نصف دوائر.</figcaption> </figure>



شكل ٦.٢٩: *
جيوديسيات فيشر-راو

البرهان (مخطّط)

الخطوة 1 (التماثل): طول منحنى لا يتغيّر بعكس اتجاهه $\Rightarrow d_F(p,q) = d_F(q,p)$.

الخطوة 2 (المثلّث): بوصل منحنى من p إلى r ثمّ من r إلى q نحصل على منحنى من p إلى q $\Rightarrow d_F(p,q) \le d_F(p,r) + d_F(r,q)$.

الخطوة 3 (برنولي): بـ $p = \sin^2\varphi$ صار المتر (من 12-3.29) $ds^2 = 4d\varphi^2$ المسافة على المتشعّب = طول القوس $2|\varphi_1 - \varphi_2| =$، وهو (20.29)؛ والصيغة الثانية من $\cos(\varphi_1-\varphi_2) = \sqrt{pq}+\sqrt{(1-p)(1-q)}$. القطر: $d_F \le \pi \Rightarrow \varphi \in [0,\pi/2]$. ■

الخطوة 4 (الغاوسي): بـ $u = \mu/\sqrt{2}$ يصير $ds^2 = 2\frac{du^2+d\sigma^2}{\sigma^2}$، أي $\sqrt{2}\times$ متر نصف المستوي الزائدي ذي الانحناء -1؛ ومسافته $\cosh^{-1}\!\left(1+\frac{\|z_1-z_2\|^2}{2\sigma_1\sigma_2}\right)$ (21.29) $\Rightarrow$. ■

الخطوة 5 (تشينتسوف): برهانٌ تصنيفي (categorical) طويل؛ خلاصته أنّ شرط الثبات تحت كلّ تطبيقات ماركوف (التي تعمّم الإحصاء الكافي) يقيّد المتر ليكون من الشكل $A\cdot\mathbb{E}[\partial_i\ell\,\partial_j\ell] + B\cdot\mathbb{E}[\partial_i\ell]\mathbb{E}[\partial_j\ell]$، والحدّ الثاني صفر بـ (6.29) $\Rightarrow A\cdot I$. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.29): مسافة توزيعين ثنائيين المعطيات: $p = 0.5$، $q = 0.9$. المطلوب: d_F. الحل: الخطوة 1: $\mathrm{BC} = \sqrt{0.45} + \sqrt{0.05} = 0.6708 + 0.2236 = 0.8944$. الخطوة 2: $\arccos(0.8944) = 0.4636$ rad. الخطوة 3: $d_F = 2(0.4636) = 0.9273$. النتيجة: مسافة معلوماتية $0.93 \approx$ من أقصى مسافة $\pi \approx 3.14$. الربط بالذكاء الاصطناعي: مقياس متماثل لمقارنة مخرجات مصنّفين لا يتأثّر بترتيب المقارنة.

مثال (29.7-2): القطر الأقصى المعطيات: $p = 0$ مقابل $q = 1$ (يقينان متعاكسان). المطلوب: d_F. الحل: الخطوة 1: $\mathrm{BC} = 0 \Rightarrow \arccos(0) = \pi/2$. الخطوة 2: $d_F = \pi \approx 3.1416$. النتيجة: قطر متشعّب برنولي = π (نصف دائرة نصف قطرها 2). الربط بالذكاء الاصطناعي: يحدّد مقياساً مطلقاً لمدى «بُعد» تنبؤين عن بعضهما.

مثال (29.7-3): التوافق الموضعي مع فيشر المعطيات: $p = 0.5$، $\varepsilon = 0.01$. المطلوب: $d_F(p, p+\varepsilon)$ مقابل $\sqrt{I}\varepsilon$. الحل: الخطوة 1: $\sqrt{I} = \sqrt{4} = 2 \Rightarrow$ التقدير 0.02. الخطوة 2: الدقيق: $\varphi_1 = \arcsin(\sqrt{0.5}) = 0.7854$؛ $\varphi_2 = \arcsin(\sqrt{0.51}) = \arcsin(0.71414) = 0.7954$. الخطوة 3: $d_F = 2(0.0100) = 0.0200$ ✓. النتيجة: مسافة فيشر–راو = التكامل الموضعي لطول فيشر. الربط بالذكاء الاصطناعي: تحقّق من أنّ مسافة راو هي «التكامل» الصحيح لمتر فيشر.

مثال (29.7-4): توزيع فئوي بثلاثة أصناف المعطيات: $p = (0.5, 0.25, 0.25)$ مقابل $q = (1/3, 1/3, 1/3)$. المطلوب: d_F. الحل: الخطوة 1: $\mathrm{BC} = \sqrt{0.5/3} + 2\sqrt{0.25/3} = 0.4082 + 2(0.2887) = 0.9856$. الخطوة 2: $\arccos(0.9856) = 0.1699$ rad. الخطوة 3: $d_F = 0.3398$. النتيجة: مسافة صغيرة رغم اختلاف بارز في الشكل — لأنّ المتر يقيس التغيّر النسبي. الربط بالذكاء الاصطناعي: مقارنة توزيعات الانتباه بين رؤوس المحوّل (ستُستخدم في الفصل 39).

مثال (29.7-5): غاوسيان بتباين متساوٍ المعطيات: $\mu_1 = 0$، $\mu_2 = 3$، $\sigma = 2$. المطلوب: d_F. الحل: الخطوة 1: المتر $ds^2 = d\mu^2/\sigma^2 \Rightarrow$ الطول $= |\Delta\mu|/\sigma$. الخطوة 2: $d_F = 3/2 = 1.5$. النتيجة: المسافة بوحدات الانحراف المعياري. الربط بالذكاء الاصطناعي: تطبيعٌ تلقائي بمقياس عدم اليقين في كلّ مقارنة توزيعية.

مثال (29.7-6): مسار أقصر من المستقيم المعطيات: $\mu_1 = 0, \sigma_1 = 1$ مقابل $\mu_2 = 2, \sigma_2 = 1$. المطلوب: d_F ومقارنته بالمسافة الإقليدية في (μ, σ). الحل: الخطوة 1: الوسيط $= \frac{4+4}{4} = 2$. الخطوة 2: $= \frac{(2)^2+2(1+1)}{4\cdot1\cdot1}$ $= \cosh^{-1}(2) = 1.3170$. الخطوة 3: $d_F = \sqrt{2}(1.3170) = 1.8627$ — أقلّ من $|\Delta\mu|/\sigma = 2$. النتيجة: الجيوديسية «تنفخ» التباين في الطريق فتقصّر المسار. الربط بالذكاء الاصطناعي: تفسير هندسي لتفوّق الاستيفاء المنحني على الخطّي في دمج الأوزان.

مثال (29.7-7): تباينان مختلفان المعطيات: μ متساوٍ، $\sigma_1 = 1$، $\sigma_2 = 4$. المطلوب: d_F. الحل: الخطوة 1: الوسيط $= \frac{34}{16} = 2.125$ $= \frac{0+2(1+16)}{4\cdot4}$. الخطوة 2: $\cosh^{-1}(2.125) = 1.3862$. الخطوة 3: $d_F = 1.9604$. النتيجة: 1.960 أكبر من $|\ln(4/1)| = 1.386$؛ لأنّ المتر يضخّم التغيّر النسبي في التباين الصغير. الربط بالذكاء الاصطناعي: تقديرات التباين الصغيرة حسّاسة جدّاً معلوماتيّاً (قارن حدّ كرامير–راو 29.4-4).

مثال (29.7-8): غاوسي متعدّد بتغاير ثابت المعطيات: $\Sigma = \mathrm{diag}(4, 1)$، $\Delta\mu = (2, 1)$. المطلوب: d_F. الحل: الخطوة 1: $\Delta^\top\Sigma^{-1}\Delta = 4/4 + 1/1 = 1 + 1 = 2$. الخطوة 2: $d_F = \sqrt{2} = 1.4142$. النتيجة: مسافة راو = مسافة ماهالانوبيس تماماً. الربط بالذكاء الاصطناعي: كلّ مقاييس المسافة في كشف الشذوذ المتعدّد هي في الأصل مسافات فيشر–راو.

مثال (29.7-9): مقارنة نماذج تصنيف المعطيات: نموذجان يعطيان على نفس المُدخل $(0.8, 0.2)$ و $(0.6, 0.4)$، والصحيح واحد ساخن. المطلوب: أيّ مقياس نستخدم؟ الحل: الخطوة 1: KL غير متماثل: $D(\text{صحيح}\|m_1) = \ln(1/0.8) = 0.223$؛ $D(m_1\|\text{صحيح})$ غير معرّف (الاحتمال صفر للصنف الثاني!). الخطوة 2: d_F محدود ومعرّف دائماً: $d_F(m_1, \text{واحد ساخن}) = 2\arccos(\sqrt{0.8}) = 2(0.4636) = 0.9273$. النتيجة: راو يتعامل مع الاحتمالات الصفرية بسلامة، بخلاف KL. الربط بالذكاء الاصطناعي: سبب استخدام مقاييس هندسية في تقييم معايرة النماذج.

مثال (29.7-10): مسافات الوثائق في نمذجة المواضيع المعطيات: وثيقتان بتوزيعي مواضيع p, q على 50 موضوعاً. المطلوب: مقياس مسافة. الحل: الخطوة 1: $d_F = 2\arccos\sum_k \sqrt{p_k q_k}$. الخطوة 2: حساب الجذر التربيعي لكلّ موضوع (عملية عنصرية سريعة). النتيجة: مقياس متماثل ومحدود بـ π يسهل تطبيعه. الربط بالذكاء الاصطناعي: أساس «مسافة هيلينغر» المستخدمة في تجميع الوثائق (وهي مرتبطة بها بـ $d_F = 2\arccos(1 - H^2)$).

مثال (11-7.29): جدول مقارنة شامل المعطيات: برنولي $p = 0.5$ مقابل $q = 0.9$. المطلوب: KL KL، العكسي، هيلينغر، راو. الحل: الخطوة 1: $D(p\|q) = 0.5\ln(0.5/0.9) + 0.5\ln(0.5/0.1) = 0.5108$ nats. الخطوة 2: $D(q\|p) = 0.9\ln(1.8) + 0.1\ln(0.2) = 0.3681$ nats (لا يتماثل!). الخطوة 3: $H^2 = 1 - \mathrm{BC} = 1 - 0.8944 = 0.1056$. الخطوة 4: $d_F = 2\arccos(0.8944) = 0.9273$. النتيجة: راو وحده متر (متماثل + مثلّث)؛ الباقي تباعدات. الربط بالذكاء الاصطناعي: اختيار المقياس يقرّر سلوك التجميع والاسترجاع.

مثال (12-7.29): الاستيفاء الجيوديسي المعطيات: برنولي $p = 0.1$ و $q = 0.5$. المطلوب: النقطة الوسطى على الجيوديسية مقابل الوسط الحسابي. الحل: الخطوة 1: $\varphi_1 = \arcsin(\sqrt{0.1}) = 0.3218$؛ $\varphi_2 = \arcsin(\sqrt{0.5}) = 0.7854$. الخطوة 2: الوسط الجيوديسي $\varphi = 0.5536 \Rightarrow p = \sin^2(0.5536) = 0.2768$. الخطوة 3: الوسط الحسابي $= 0.3$. النتيجة: فرق $0.023 \approx$ — الجيوديسية تميل نحو الحدود حيث المتر أثقل. الربط بالذكاء الاصطناعي: دمج نماذج (model soup) بالاستيفاء الجيوديسي لا الحسابي.

مثال (13-7.29): التفاف التوزيعات في التقطير (distillation) المعطيات: توزيع المعلم q وتلميذ p_θ على المفردات. المطلوب: لماذا التقطير بأقصى احتمال يختلف عن تقليل راو؟ الحل: الخطوة 1: أقصى احتمال يقلّل $D(q\|p)$ $\Rightarrow$ سلوك شامل (يوزّع الاحتمال على المفردات). الخطوة 2: تقليل راو يعاقب بُعد التوزيعين هندسيّاً بلا انحياز للنمط. النتيجة: اختيار الهدف يقرّر «سلاسة» مخرجات التلميذ. الربط بالذكاء الاصطناعي: تبرير هندسي لدرجة الحرارة (temperature) في التقطير.

مثال (14-7.29): حساب الجيوديسية عدديّاً المعطيات: عائلة عامّة بلا صيغة مغلقة. المطلوب: المعادلة الواجب حلّها. الحل: الخطوة 1: معادلة الجيوديسية: $\ddot\gamma^k + \Gamma^{(0)k}_{ij}\dot\gamma^i\dot\gamma^j = 0$. الخطوة 2: $\Gamma^{(0)}_{ijk} = \frac{1}{2}\mathbb{E}[\partial_i\ell\,\partial_j\ell\,\partial_k\ell]$ للعائلة الأُسّية (من 16.29 بـ $\alpha = 0$). الخطوة 3: حلّ مسألة قيم حدّية (BVP) ثمّ حساب الطول بالتكامل. النتيجة: تكلفة عددية معقولة للأبعاد الصغيرة ($d < 50$). الربط بالذكاء الاصطناعي: يُستخدم في تحليل مسارات التدريب بوصفها منحنيات على المتشعّب.

مثال (15-7.29): معيار فيشر–راو للتعميم المعطيات: شبكة بوزنين $\theta = (0.5, 2)$، فيشر تجريبي قطري $(4, 0.25)$. المطلوب: معيار فيشر–راو. الحل: الخطوة 1: $\theta^\top I\theta = \sum_i \theta_i^2 I_{ii} = \|\theta\|^2_{FR}$. الخطوة 2: $0.25 \times 4 + 4 \times 0.25 = 1 + 1 = 2$. الخطوة 3: $\|\theta\|_{FR} = \sqrt{2} = 1.414$. النتيجة: معيار يقيس تعقيد النموذج **بوحدة المعلومة** لا بوحدة الأرقام. الربط بالذكاء الاصطناعي: ثبت تجريبيّاً ارتباطه بالتعميم أفضل من معيار الأوزن الإقليدي.

أخطاء شائعة

- استخدام KL بوصفه مسافة (ليس متماثلاً ولا يحقّق المثلّث).
- تطبيق صيغة (20.29) على عائلة غير برنولي (لكلّ عائلة صيغتها).
- نسيان عامل المقياس عند مقارنة مراجع مختلفة (بعضها يعرّف المتر بـ $\frac{1}{4}I$).
- الظنّ أنّ الاستيفاء الخطّي بين توزيعين = الجيوديسية.
- تجاهل أنّ d_F قد لا تكون مغلقة الشكل فنلجأ إلى حلّ عددى.

المبرهنة: لتكن $q(z) = p(z \mid x;\theta_t)$ توزيع المتغيّرات الكامنة. فإنّ تفكيك لوغاريتم الاحتمال

$$\log p(x;\theta) \;=\; \underbrace{\mathbb{E}_q\big[\log p(x,z;\theta)\big] + H(q)}_{\mathcal{L}(q,\theta)} \;+\; \underbrace{D_{\mathrm{KL}}\big(q\,\|\,p(z\mid x;\theta)\big)}_{\geq 0} \tag{23.29}$$

هو **مترابحة فيثاغورس معلوماتية** (17.29) بعينها، وخوارزمية EM تتألّف من إسقاطين متعاقبين:

$$\text{E-step (إسقاط e):}\quad q_{t+1} \;=\; \arg\min_{q} D_{\mathrm{KL}}\big(q \,\|\, p(z \mid x;\theta_t)\big) = p(z \mid x;\theta_t) \tag{24.29}$$

$$\text{M-step (إسقاط m):}\quad \theta_{t+1} \;=\; \arg\max_{\theta} \mathbb{E}_{q_{t+1}}\big[\log p(x,z;\theta)\big] \tag{25.29}$$

وفي الشبكات العميقة، تُقرَّب مصفوفة فيشر لكلّ طبقة بجداء كرونيكر

$$F_\ell \;\approx\; A \otimes G, \qquad A = \mathbb{E}[a a^\top], \quad G = \mathbb{E}[g g^\top], \qquad F_\ell^{-1} \approx A^{-1} \otimes G^{-1} \tag{26.29}$$

ويُستخدم المتر القطري عقاباً في التعلّم المستمر

$$\text{EWC:}\quad \tilde{L}(\theta) = L(\theta) + \frac{\mu}{2}\sum_i F_{ii}\,(\theta_i - \theta_i^\star)^2, \qquad \mathrm{Sal}_i = \frac{1}{2} F_{ii}\theta_i^2 \tag{27.29}$$

جدول الرموز

الرمز	المعنى	ملاحظة
z	متغيّرات كامنة	
$\mathcal{L}$	الحدّ الأدنى للتغيّر (ELBO)	من الفصل 18
إسقاط e	يقلّل $D(p\|q)$	تحديث التوزيع على المتغيّرات الكامنة
إسقاط m	يقلّل $D(q\|p)$	تحديث معلمات النموذج
a, g	تفعيلات الدخل وتدرّج المخرج للطبقة	لبنة K-FAC
F_{ii}	قطر فيشر	أهمّية الوزن في EWC/OBD

الرسم

<figure> الشكل<figcaption> 7.29: EM يتناوب بين إسقاط e (خطوة E) وإسقاط m (خطوة M) بين متشعّب البيانات الكاملة ومتشعّب النموذج، وكلّ دورة ترفع الاحتمال رتيباً.</figcaption></figure>

البرهان

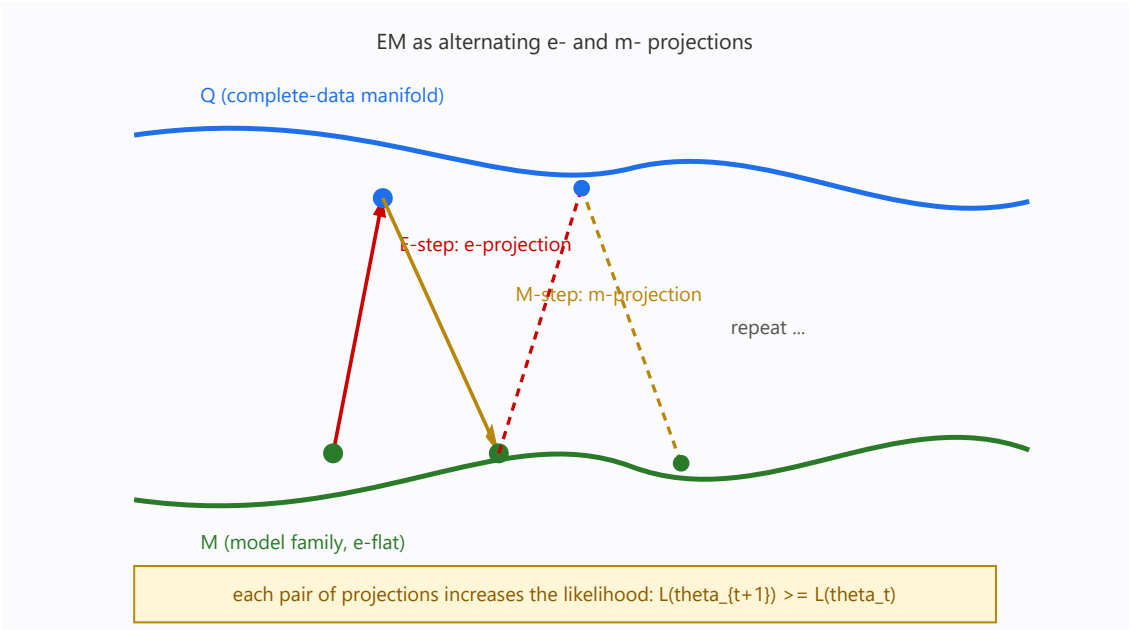
الخطوة 1 (التفكيك): من تعريف الاحتمال الشرطي: $\log p(x;\theta) \;=\; \log \frac{p(x,z;\theta)}{p(z\mid x;\theta)} \;=\; \log p(x,z;\theta) - \log q + \log q - \log p(z\mid x;\theta) = D_{\mathrm{KL}}(q\|p(z\mid x;\theta)) \geq 0$، بأخذ التوقّع تحت q يظهر الطرفان في (23.29)، والثاني منهما $\geq$ الأول. ■

الخطوة 2 (خطوة E = إسقاط e): تعظيم $\mathcal{L}$ على q مع تثبيت θ_t يعادل تصغير $D_{\mathrm{KL}}(q\|p(z \mid x;\theta_t))$، والحلّ الأمثل هو المساواة $q = p(z\mid x;\theta_t)$ — وهو **الإسقاط e** على المتشعّب المطلوب. ■

الخطوة 3 (خطوة M = إسقاط m): تعظيم $\mathbb{E}_q[\log p(x,z;\theta)]$ على عائلة أُسّية يعني مطابقة الإحصاء الكافي المتوقّع تحت q — أي **الإسقاط m** (قارن 6.29-7). ■

الخطوة 4 (الرتابة): بعد خطوة E صار الحدّ الثاني في (23.29) صفراً، وخطوة M ترفع الحدّ الأوّل، وإعادة حساب q تُدخل انخفاضاً في الحدّ الأوّل لا يزيد على ما كسبناه $\Rightarrow \log p(x;\theta_{t+1}) \geq \log p(x;\theta_t)$. ■

الخطوة 5 (K-FAC): للطبقة الكاملة، $\nabla_W \ell = g\, a^\top \Rightarrow \mathrm{vec}$ يعطي $g \otimes a$ $\Rightarrow F = \mathbb{E}[(g\otimes a)(g\otimes a)^\top] = \mathbb{E}[gg^\top]\otimes\mathbb{E}[aa^\top]$ (تقريباً باستقلال a و g) $\Rightarrow$ (26.29) وخاصّة المعكوس. ■



شكل ٧.٢٩: *
EM كإسقاطات متعاقبة

خمسة عشر مثالاً محلولاً

مثال (1-8.29): خليط غاوسي — خطوة E إسقاط e المعطيات: خليط من $\mathcal{N}(0,1)$ و $\mathcal{N}(3,1)$ بأوزان متساوية، نقطة $x = 1$. المطلوب: المسؤوليات (responsibilities). الحل: الخطوة 1: $\varphi(1) = 0.2420$، $\varphi(-2) = 0.0540$. $\varphi(1-3) = \varphi(1)$. الخطوة 2: الأوزان: $0.5(0.2420) = 0.1210$، $0.5(0.0540) = 0.0270$؛ المجموع 0.1480. الخطوة 3: $r_1 = 0.8176$، $r_2 = 0.1824$. النتيجة: $q(z) = (0.8176, 0.1824)$ — الإسقاط e الذي يجعل D_{KL} صفراً. الربط بالذكاء الاصطناعي: خطوة E ليست «حساب احتمالات» فحسب، بل إسقاط معلوماتي أمثل.

مثال (2-8.29): خطوة M إسقاط m المعطيات: نقطتان $x = 1$ و $x = 4$ بمسؤوليات $r_1 = (0.8, 0.2)$ و $r_2 = (0.3, 0.7)$ للمكوّن الأوّل. المطلوب: تحديث μ_1. الحل: الخطوة 1: متوسط مرجّح: $\mu_1 = \frac{0.8(1)+0.3(4)}{0.8+0.3} = \frac{0.8+1.2}{1.1} = 1.818$. النتيجة: مطابقة العزوم المرجّحة = الإسقاط m. الربط بالذكاء الاصطناعي: كلّ خطوة M في العائلات الأُسّية هي مطابقة عزوم (لا اشتقاق).

مثال (3-8.29): رتابة الاحتمال المعطيات: $\log p(x;\theta_0) = -12.4$. المطلوب: ما يضمنه EM. الحل: الخطوة 1: بعد خطوة E: الحدّ الثاني $= 0$، $\mathcal{L} = -12.4$. الخطوة 2: بعد خطوة M: $\mathcal{L} \geq -12.4 \Rightarrow \log p(x;\theta_1) \geq -12.4$. النتيجة: رتابة مضمونة هندسيّاً (لا تخمين). الربط بالذكاء الاصطناعي: يفسّر استقرار EM مقارنةً بتدرّج الاحتمال المباشر.

مثال (4-8.29): خليط غير أُسّي المعطيات: خليط بمكوّنات ذات تباينات مجهولة وأوزان خلط متغيّرة. المطلوب: هل تُحلّ خطوة M بشكل مغلق؟ الحل: الخطوة 1: الأوزان تدخل لاخطّياً $\Rightarrow$ العائلة ليست أُسّية في معلماتها مجتمعة. الخطوة 2: نحتاج تحسيناً داخليّاً في كلّ خطوة M (أو تدرّجاً طبيعياً مصغّراً). النتيجة: غياب الاستواء المزدوج = غياب الحلّ المغلق. الربط بالذكاء الاصطناعي: يقابل صعوبة تدريب نماذج خليط الخبراء في المحوّلات (الفصل 39).

مثال (5-8.29): EM بوصفه تدرّجاً طبيعياً المعطيات: EM مقابل التدرّج الطبيعي على نفس الهدف. المطلوب: العلاقة. الحل: الخطوة 1: EM = تعظيم–تصغير (majorize–minimize) بخطوة كاملة في فضاء المعلومة. الخطوة 2:

التدرّج الطبيعي بخطوة 1 $\rightarrow$ η يقترب من سلوك EM في العائلات الأُسّية. النتيجة: EM «تدرّج طبيعي بخطوة وحدة» في حالات واسعة. الربط بالذكاء الاصطناعي: يوحّد خوارزميتين تبدوان مختلفتين في إطار هندسي واحد.

مثال (29.8-6): الحقل المتوسط إسقاط m أيضاً المعطيات: استدلال متغيّري بقيود $q = \prod_j q_j$. المطلوب: التفسير الموحّد مع EM. الحل: الخطوة 1: كلا الطريقتين يقلّلان $D(q\|p)$ على عائلة قيديّة. الخطوة 2: الفرق: في EM القيد هو $q(z|x)$ التامّ؛ في VI القيد هو الانفصال. النتيجة: EM و VI أخوان هندسيّان (إسقاطان m على متشعّبين مختلفين). الربط بالذكاء الاصطناعي: يبرّر نقل الأفكار بينهما (مثل التحديثات المجمّعة).

مثال (29.8-7): انهيار النمط في VI المعطيات: تقريب توزيع ثنائي النمط بتقليل $D(q\|p)$ (KL العكسي). المطلوب: النتيجة المتوقّعة. الحل: الخطوة 1: $D(q\|p)$ عقابه على وضع q حيث p صغيرة $\Rightarrow$ يتجنّب تغطية النمط الثاني. الخطوة 2: النتيجة: q يلتصق بنمط واحد. النتيجة: انهيار النمط ظاهرة هندسية لاتجاه التباعد لا خللٌ في الخوارزمية. الربط بالذكاء الاصطناعي: التبرير النظري لسلوك VAE المعروف (سيُفصّل في الفصل 41).

مثال (29.8-8): K-FAC — تفكيك طبقة المعطيات: طبقة $a \in \mathbb{R}^{784}$، $g \in \mathbb{R}^{256}$، حجم دفعة 128. المطلوب: تقدير A و G. الحل: الخطوة 1: $A = \frac{1}{128}\sum_n a_n a_n^\top$ (784×784)؛ $G = \frac{1}{128}\sum_n g_n g_n^\top$ (256×256). الخطوة 2: متوسطات متحرّكة عبر الخطوات لاستقرار التقدير. الخطوة 3: الخطوة الطبيعية: $\Delta W = -\eta\, G^{-1}(\nabla_W L)A^{-1}$. النتيجة: تكلفة التخزين 680 ألف عنصر بدل 40 مليار. الربط بالذكاء الاصطناعي: الطريقة الوحيدة العملية لتقريب التدرّج الطبيعي على شبكات كبيرة.

مثال (29.8-9): تخميد K-FAC المعطيات: A بقيمة ذاتية صغرى 10^{-8}. المطلوب: أثر ذلك وكيفية العلاج. الحل: الخطوة 1: A^{-1} يعطي 10^{8} $\Rightarrow$ تحديث منفجر. الخطوة 2: أضف $\lambda = 10^{-3}$ للقطر: القيمة تصير $10^{-3} \approx$ $\Rightarrow$ معكوسها 10^{3}. النتيجة: تخميد Tikhonov ضروري دائماً مع المتر التقديري. الربط بالذكاء الاصطناعي: كلّ مكتبات K-FAC تجعل التخميد إعداداً إلزاميّاً لا اختياريّاً.

مثال (29.8-10): EWC — فيشر بوصفه «ذاكرة» المعطيات: مهمة سابقة انتهت عند $\theta^\star$، فيشر قطري F_{ii} لوزنين: $F_1 = 4$ و $F_2 = 100$. المطلوب: أيّ وزن نحمي أكثر؟ الحل: الخطوة 1: العقاب $\frac{\mu}{2}\sum F_{ii}(\theta_i - \theta_i^\star)^2 \Rightarrow$ انزياح مقداره 0.1 يكلّف: 0.02μ و 0.5μ. الخطوة 2: النسبة 25 $\Rightarrow$ الوزن الثاني أهمّ بـ 25 مرّة للمهمة السابقة. النتيجة: فيشر يحدّد «أيّ الأوزان تحمل معلومة المهمة السابقة». الربط بالذكاء الاصطناعي: الأساس النظري لمنع النسيان الكارثي في التعلّم المستمر.

مثال (29.8-11): تقليم الأوزان بدليل فيشر (Optimal Brain Damage) المعطيات: وزنان $\theta_1 = 0.01$ مع $F_{11} = 100$ مقابل $\theta_2 = 2$ مع $F_{22} = 0.25$. المطلوب: أيّهما يُقلّم؟ الحل: الخطوة 1: مقياس الأهمّية: $\frac{1}{2}F_{11}\theta_1^2 = \frac{1}{2}(100)(10^{-4}) = 0.005$. الخطوة 2: $\frac{1}{2}F_{22}\theta_2^2 = \frac{1}{2}(0.25)(4) = 0.5$. النتيجة: نقلّم الأول (أهمّية أقلّ بـ 100 مرّة) رغم أنّه «أكبر معلوماتيّاً لكلّ وحدة». الربط بالذكاء الاصطناعي: يفسّر لماذا التقليم بالمقدار وحده (magnitude pruning) قد يكون مضلّلاً.

مثال (29.8-12): تقريب لابلاس وفيشر المعطيات: تقريب لابلاس للتوزيع البعدي: $p(\theta|D) \approx \mathcal{N}(\theta^\star, H^{-1})$ بـ $H = -\nabla^2 \log p$. المطلوب: استبدال فيشر. الحل: الخطوة 1: عند $\theta^\star$، (MLE) $-\mathbb{E}[\nabla^2 \log p] = nI(\theta^\star)$ (تقريب غاوس–نيوتن). الخطوة 2: $nI \approx H \Rightarrow$ التغاير البعدي $(nI)^{-1} \approx$ — عائدون إلى كرامير–راو (29.7). النتيجة: فيشر = هسّية التوزيع البعدي في تقريب غاوس–نيوتن. الربط بالذكاء الاصطناعي: يربط هذا الفصل بالفصل 18 (MLE/MAP) والفصل 25 (التحسين البايزي).

مثال (29.8-13): فيشر في الشبكات البايزية المعطيات: شبكة بأوزان عشوائية، هدف «قياس عدم يقين النموذج». المطلوب: دور فيشر. الحل: الخطوة 1: تقريب لابلاس يعطي تغايراً بايزياً من I^{-1}. الخطوة 2: التباين التنبؤي يحسب

بنشر هذا التغاير عبر الشبكة linearized). (Laplace النتيجة: عدم يقين معاير بتكلفة قطر فيشر فقط. الربط بالذكاء الاصطناعي: أساس Laplace» «approximation الحديثة للشبكات العميقة.

مثال (29.8-14): تدرّج السياسة الطبيعي في الروبوتات المعطيات: ذراع روبوتية بسيطة استمرارية، حجم دفعة 64 مساراً. المطلوب: كيف نثبّت التدريب؟ الحل: الخطوة 1: متر السياسة $I = \mathbb{E}[\nabla \log \pi \nabla \log \pi^\top]$ يقدَّر من الدفعة. الخطوة 2: قيد KL بـ $\delta = 0.01$ يمنع تغيّراً مفاجئاً في السلوك الحركي. النتيجة: تعلّم مستقرّ مقابل انهيار متكرّر بالتدرّج العادي. الربط بالذكاء الاصطناعي: سبب شيوع PPO في التحكّم المستمر (سيُفصّل في الفصل 44).

مثال (29.8-15): خريطة الطريق إلى الفصول القادمة المعطيات: متر فيشر $I(\theta)$ لشبكة عميقة. المطلوب: ما الذي ستستفيد منه الأجزاء 6–8؟ الحل: الخطوة 1: الجزء السادس (نظرية التعلّم): حدود التعميم بمعايير معلوماتية. الخطوة 2: الجزء السابع: NTK (الفصل 40) — متر فيشر في النظام اللانهائي العرض، والتوليد (41) — تباعدات على المتشعّب، والنقل الأمثل (42) — متر آخر على فضاء التوزيعات. الخطوة 3: الجزء الثامن: الهندسة التفاضلية (48) — التعميم النهائي لكلّ ما سبق. النتيجة: متر فيشر هو الخيط الذي يربط نظرية المعلومات برياضيات الشبكات. الربط بالذكاء الاصطناعي: خارطة القراءة للقارئ الذي يريد العمق لا التفاصيل المتفرّقة.

أخطاء شائعة

- اعتبار EM خوارزمية تحسين عامّة (هي إسقاطات على متشعّب معلوماتي، قد تتعثّر عند نقاط السرج).
- استخدام فيشر التجريبي (بالبيانات) حيث يلزم فيشر النموذج في EWC/K-FAC.
- تقليم الأوزان بالمقدار وحده وتجاهل F_{ii}.
- نسيان تقريب K-FAC يفترض استقلال a و g (وهو تقريب لا تطابق).
- الظنّ أنّ VI يقلّل نفس تباعد EM (الاتجاه معكوس والنتائج مختلفة جذريّاً).

ملخّص النظريات

النظرية	المفهوم	الأهمّية
2.29 المتشعّب والمتر	$I = E[\nabla\ell\nabla\ell^\top]$	فضاء التوزيعات متشعّب ريماني
3.29 التكافؤ المحلّي	$D_{KL} = \frac{1}{2}d^\top Id + O(d^3)$	فيشر = هسّية KL
4.29 كرامير–راو	$\mathrm{Cov} \succeq I_n^{-1}$	حدّ دقّة كلّ مقدّر
5.29 التدرّج الطبيعي	$\tilde\nabla = I^{-1}\nabla L$	تحسين ثابت تحت المُعلمة
6.29 الاستواء المزدوج	ψ, φ و $\Gamma^{(\alpha)}$	KL تباعد بريغمان + فيثاغورس
7.29 مسافة راو	$d_F = \inf \int \sqrt{\dot\gamma^\top I \dot\gamma}$	متر حقيقي (وحدانية تشينتسوف)
8.29 الإسقاطات	متعاقبان e/m = EM	K-FAC و EWC والتقليم

عشرون تمريناً (مع إجابات مختصرة)

١. تعريف متر فيشر؟ $(I_{ij} = \mathbb{E}[\partial_i \ell\, \partial_j \ell])$

٢. التكافؤ الثاني؟ $(I = -\mathbb{E}[\nabla^2 \ell])$

٣. متوسط الدرجة؟ (صفر)

٤. معلومة برنولي عند p؟ $(1/(p(1-p)))$

٥. معلومة بواسون؟ $(1/\lambda)$

٦. متر الغاوسي (μ, σ)؟ $(\mathrm{diag}(1/\sigma^2,\, 2/\sigma^2))$

٧. قانون تحوّل المتر؟ $(I(\phi) = J^\top I(\theta) J)$

٨. تقريب KL الموضعي؟ $(\frac{1}{2} d^\top I d)$

٩. D_{KL} متر؟ (لا: لاتماثل ولا مثلّث)

١٠. صيغة كرامير–راو؟ $(\mathrm{Cov} \succeq I_n^{-1})$

١١. أثر حجم العيّنة على المعلومة؟ $(I_n = n I_1)$

١٢. صيغة التدرّج الطبيعي؟ $(I^{-1} \nabla L)$

١٣. لماذا NG ثابت تحت المُعْلمة؟ (لأنّ $I^{-1}\nabla L$ يتحوّل كمتّجه)

١٤. NG في عائلة أُسّية يساوي ماذا؟ $(\nabla_\mu L)$

١٥. الكمون المزدوج لبرنولي؟ (سالب الإنتروبيا $-H$)

١٦. صيغة مسافة راو لبرنولي؟ $(2 \arccos(\sqrt{pq} + \sqrt{(1-p)(1-q)}))$

١٧. أقصى مسافة راو لبرنولي؟ (π)

١٨. متر الغاوسي بوصفه هندسة زائدية؟ $(ds^2 = (d\mu^2 + 2 d\sigma^2)/\sigma^2)$

١٩. خطوتا EM هندسيّاً؟ (إسقاط e ثمّ إسقاط m)

٢٠. تقريب K-FAC؟ $(F \approx A \otimes G)$، معكوسه $A^{-1} \otimes G^{-1}$

فهرس الرموز

الرمز	المعنى
$\ell = \log p_\theta$	اللوغاريتم الاحتمالي
$\partial_i \ell$	مكوّنة الدرجة
$I(\theta)$, g_{ij}	متر فيشر–راو
ds^2	عنصر الطول المعلوماتي
$\tilde{\nabla}$	التدرّج الطبيعي
θ, μ	إحداثيات e و m
ψ, φ	كمون لوغاريتم القاسم ومزدوجه
$\Gamma^{(\alpha)}$	اتصال α
d_F	مسافة فيشر–راو
BC	معامل بهتّشاريا

مراجع

- Amari — *Information Geometry and Its Applications* (المرجع المحوري للفصل).
- Nagaoka & Amari — *Geometry Information of Methods* (الاستواء المزدوج والاتصالات α).
- Čencov — *Statistical Decision Rules and Optimal Inference* (وحدانية المتر، 1972).
- Rao — «Information and the accuracy attainable in the estimation of statistical parameters» (1945).
- Cramér — *Mathematical Methods of Statistics* (متراجحة كرامير–راو).
- Amari — «Natural Gradient Works Efficiently in Learning» (1998).
- Grosse & Martens — «Optimizing Neural Networks with Kronecker-factored Approximate Curvature» (K-FAC, 2015).
- Kirkpatrick et al. — «Overcoming catastrophic forgetting in neural networks» (EWC, 2017).
- LeCun, Denker & Solla — «Optimal Brain Damage» (أهمّية فيشر في التقليم، 1990).
- Thomas & Cover — *Elements of Information Theory* (الفصول السابقة من الجزء الخامس).

خاتمة الجزء الخامس: بدأنا بمقياسٍ للكمّ (الإنتروبيا، الفصل 26)، ثمّ بمقياسٍ للتباعد (KL و f–ديفرجنس، الفصل 27)، ثمّ بحدودٍ فيزيائية (السعة والترميز و MDL، الفصل 28)، وانتهينا بـ **هندسة**: فضاء التوزيعات متشعّبٌ متره فيشر، وKL انحناؤه الموضعي، والتدرّج الطبيعي هو المشي على سطحه بأقصر طريق. بهذا صار لدينا كلّ ما يلزم للانتقال من «قياس المعلومة» إلى «التعلّم من البيانات»: **الجزء السادس — نظرية التعلّم الإحصائي**، بدءاً من إطار ERM وSRM ومقايضة التحيز–التباين (الفصل 30).

القسم VI

نظرية التعلم الإحصائي

نبذة عن هذا الجزء

جاء النموذج وحقّق خطأً صفرياً على بيانات التدريب: هل تعلّم أم حفظ؟ هذا الجزء يجيب رياضيّاً. نبدأ بـ**إطار التعلّم الإحصائي**: الخطأ التجريبي مقابل الخطأ الحقيقي، ومقايضة التحيز والتباين التي تحكم كل اختيار نموذج. ثم **بُعد VC وحدّة راديماخر** لقياس غنى عائلة النماذج عدّاً، و**نظرية PAC** التي تمنح ضمانات تعلّمٍ صريحة الاحتمال والخطأ، مع نظرية التعزيز وتعقيدها الحسابي. ثم نهتم بخصلٍ أخفّ في التدقيق لكنّها أعمق أثراً: **الاستقرار الخوارزمي** والخصوصيّة التفاضلية DP، حيث التعميم يولد من ثبات الخوارزمية لا من صغر عائلتها. ونختم بالجبهة الأحدث: **حدود التعميم في الشبكات العميقة** — PAC-Bayes، والضغط، والانحياز الضمني للتدرّج، والهبوط المزدوج، ونواة NTK. هنا تتحوّل «الخبرة الهندسية» في ضبط النموذج إلى مبرهنة تُقرأ وتُستشهد بها. **فصول الجزء:** إطار التعلّم وERM/SRM · بُعد VC وراديماخر · نظرية PAC والتعزيز · الاستقرار الخوارزمي والخصوصيّة · حدود التعميم في الشبكات العميقة.

فصول هذا الجزء

- **الفصل 30.** إطار التعلّم: ERM، SRM، والتحيز–التباين
- **الفصل 31.** بُعد VC، مترابحات Rademacher، والتركيز
- **الفصل 32.** نظرية PAC والتعلّم القابل للتعلّم
- **الفصل 33.** الاستقرار الخوارزمي والتعميم
- **الفصل 34.** حدود التعميم في الشبكات العميقة

إطار التعلّم: ERM، SRM، والتحيز–التباين

«التعلّم ليس حفظاً للعيّنة؛ إنّه تخمينٌ محسوب لما لم نره.»

الأجزاء الأولى (1–4) أعطتنا الأدوات: خطّية وتفاضل واحتمال وتحسين. والجزء الخامس أعطانا مقياساً للمعلومة وهندسةً للتوزيعات. الآن نصل إلى **السؤال المركزي لتعلّم الآلة**: متى — وبأيّ ضمان — يكون ما تعلّمته من العيّنة صالحاً لما لم أرَهُ؟ هذا الفصل يضع الإطار الرسمي الذي ستُبنى عليه كلّ فصول هذا الجزء: فضاء الفرضيات، خطر التعميم، مبدأ تقليل الخطر التجريبي (ERM)، ثمّ مبدأ تقليل الخطر البنيوي (SRM)، ثمّ تحليل التحيز–التباين الذي يفسّر ظاهرتَي الإفراط والتفريط في الملاءمة، ثمّ التنظيم واختيار النموذج، وأخيراً حدود النظرية نفسها (لا غداء مجاني) وتفكيك الخطأ إلى ثلاثة مصادر.

سبع نظريات:

- **2.30 إطار التعلّم الرسمي وخطر التعميم** — ماذا نعني بـ«التعلّم» أصلاً؟
- **3.30 حدود التعميم الموحّدة ومبدأ SRM** — متى يعمّم ERM؟
- **4.30 تحليل التحيز–التباين** — تفكيك خطر التعميم.
- **5.30 التنظيم بوصفه تحكّماً في السعة** — من الحيد إلى التناثر.
- **6.30 اختيار النموذج والتحقق المتقاطع** — كيف نختار بلا تسرّب؟
- **7.30 اتساق ERM ونظرية «لا غداء مجاني»** — حدود الممكن.
- **8.30 الأخطاء الثلاثة: تقريب وتقدير وتحسين** — خريطة تشخيص عمليّة.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
$\mathcal{X}$	فضاء المُدخلات	صور، نصوص، متّجهات
$\mathcal{Y}$	فضاء المخرجات	$\{0,1\}$، $\mathbb{R}$، فئات
$\mathcal{D}$	توزيع مجهول على $\mathcal{X} \times \mathcal{Y}$	نراه فقط عبر العيّنة
$S = \{(x_i, y_i)\}_{i=1}^{n}$	عيّنة تدريب i.i.d. من $\mathcal{D}$	حجمها n
$\mathcal{H}$	فضاء الفرضيات	اختيار المصمّم (انحياز استقرائي)
$h : \mathcal{X} \to \mathcal{Y}$	فرضية (نموذج)	عنصر من $\mathcal{H}$
$\ell(h(x), y)$	دالّة الخسارة	0-1، تربيعية، إنتروبيا تقاطعية
$R(h)$	الخطر = الخسارة المتوقّعة (التعميم)	المجهول الذي نريده
$\hat{R}_S(h)$	الخطر التجريبي على S	المحسوب الذي نراه
$R^\star$	خطر بايز (أدنى خطر ممكن)	حدّ الضجيج
$\hat{h}$	مخرجات خوارزمية التعلّم $A(S)$	
$\Omega(h)$	عقاب التنظيم (سعة)	$\lambda\Omega(h)$
δ	مستوى الثقة (احتمال الفشل)	الحدود باحتمال $1-\delta$

الاتفاقيات: العيّنة i.i.d. دائماً ما لم نذكر خلاف ذلك (السلاسل الزمنية في 6.30-9). الخسائر غير سالبة ومحدودة غالباً بـ $[0,1]$ عند استخدام حدود التركيز (الفصل 17). نرمز لـ $\mathbb{E}$ بلا دليل للتوقّع تحت $\mathcal{D}$ وللعزوم تحت العيّنة بـ $\hat{\mathbb{E}}$.

التعريف–المبرهنة (إطار التعلّم الإحصائي): ليكن $\mathcal{D}$ توزيعاً مجهولاً و $S \sim \mathcal{D}^n$ عيّنةً و $\mathcal{H}$ فضاء فرضيات و ℓ دالة خسارة. نعرّف

$$R(h) \;=\; \mathbb{E}_{(x,y)\sim\mathcal{D}}\big[\ell(h(x),y)\big] \tag{1.30}$$

$$\hat{R}_S(h) \;=\; \frac{1}{n}\sum_{i=1}^{n}\ell\big(h(x_i),y_i\big) \tag{2.30}$$

$$\hat{h}_{\mathrm{ERM}} \;\in\; \arg\min_{h\in\mathcal{H}} \hat{R}_S(h) \tag{3.30}$$

$$R^\star \;=\; \inf_{h \text{ قابلة للقياس}} R(h), \qquad h^\star = \arg\min R(h) \;\; \text{(مصنّف بايز)} \tag{4.30}$$

ويسمّى $R(\hat{h}) - R^\star$ **الخطر الزائد** (excess risk) وهو يتفكّك إلى

$$R(\hat{h}) - R^\star \;=\; \underbrace{\Big(R(\hat{h}) - \inf_{h\in\mathcal{H}} R(h)\Big)}_{\text{خطأ التقدير estimation}} \;+\; \underbrace{\Big(\inf_{h\in\mathcal{H}} R(h) - R^\star\Big)}_{\text{خطأ التقريب approximation}} \tag{5.30}$$

وخوارزمية التعلّم A هي أيّ دالّة $A : S \mapsto h \in \mathcal{H}$؛ وهدفها أن يكون $R(A(S))$ صغيراً **بالمتوسط أو باحتمال عالٍ** على تكرار سحب العيّنات.

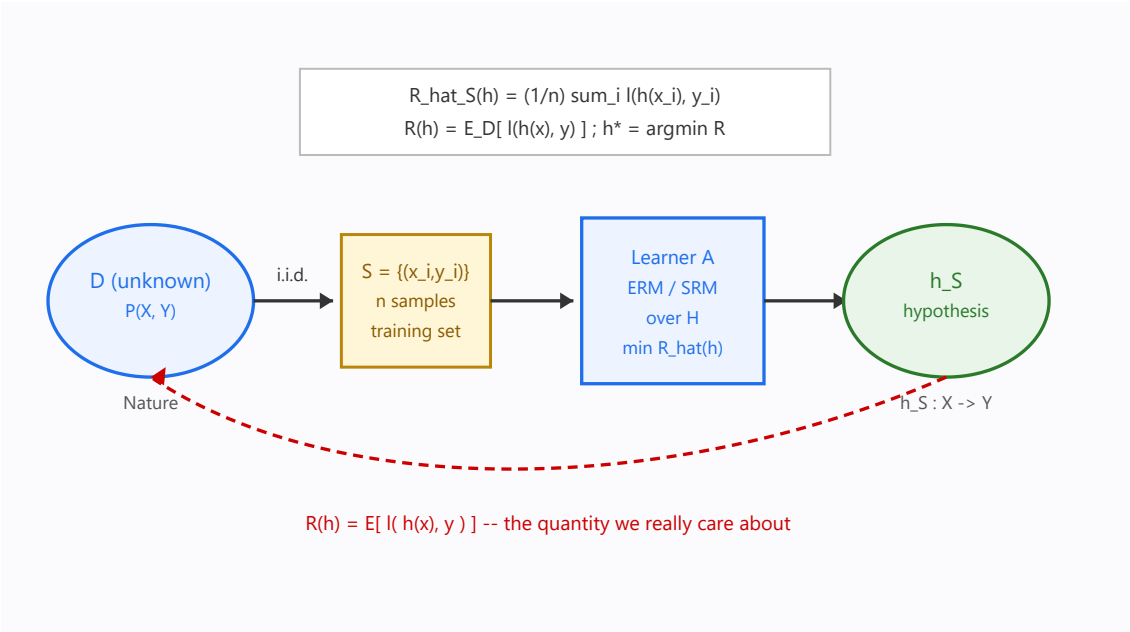
جدول الرموز

الرمز	المعنى	ملاحظة
$R(h)$	خطر التعميم	المجهول؛ لا يمكن حسابه
$\hat{R}_S(h)$	الخطر التجريبي	التقدير الوحيد المتاح
$\hat{h}$	فرضية مُخرَجة	تعتمد على $S \Rightarrow$ متغيّرة عشوائياً
$R^\star$	خطر بايز	بسبب الضجيج/التداخل في $\mathcal{D}$
$\mathcal{D}^n$	توزيع العيّنة	i.i.d. $\Rightarrow$ الضرب
خطأ التقريب	قصور $\mathcal{H}$ عن تمثيل الحقيقة	يقلّ بتوسيع $\mathcal{H}$
خطأ التقدير	قصور العيّنة S	يقلّ بزيادة n

الرسم

<figure>

</figure>
الشكل 1.30: التوزيع المجهول يولّد العيّنة، والمتعلّم يختار من $\mathcal{H}$ ما يقلّل الخطر التجريبي، بينما الهدف الحقيقي هو الخطر $R(h)$.



شكل ٣٠.١: *
إطار التعلم الإحصائي

البرهان (تأسيسي)

الخطوة 1 (الخطر توقّع): بتعريفه، $R(h) = \int \ell(h(x), y)\, d\mathcal{D}(x, y)$، وهو رقمٌ ثابت لكلّ h ثابت، لكنّه **مجهول** لأنّ $\mathcal{D}$ مجهول.

الخطوة 2 (الخطر التجريبي متغيّر عشوائي): $\hat{R}_S(h) = \frac{1}{n}\sum_i \ell(h(x_i), y_i)$ مجموعُ متغيّرات i.i.d. $\Rightarrow$ بقانون الأعداد الكبرى $\hat{R}_S(h) \xrightarrow{p} R(h)$ لكلّ h **ثابت** (لا يعتمد على S).

الخطوة 3 (المصيدة): الفرضية المُخرَجة $\hat{h} = A(S)$ **ليست** ثابتة؛ فقد صُمّمت لتناسب S، فلا يجوز تطبيق قانون الأعداد الكبرى عليها مباشرة. هذه هي مشكلة التعميم، وسيحلّها الفصل القادم (3.30) بالتقارب الموحّد. ■

الخطوة 4 (تفكيك الخطر الزائد): بإضافة وطرح $\inf_{h\in\mathcal{H}} R(h)$:

$$R(\hat{h}) - R^\star = \Big(R(\hat{h}) - \inf_{h\in\mathcal{H}} R(h)\Big) + \Big(\inf_{h\in\mathcal{H}} R(h) - R^\star\Big)$$

والحدّ الثاني ≥ 0 لأنّ $R^\star$ هو الأدنى على كلّ الدوالّ، والأوّل ≥ 0 لأنّ $R(\hat{h}) \geq \inf_{\mathcal{H}} R$. ■

الخطوة 5 (الخطر التجريبي متحيّز للأسفل): $\mathbb{E}_S[\hat{R}_S(\hat{h})] \leq \mathbb{E}_S[\hat{R}_S(h)] = R(h)$ لأيّ h ثابت؛ أي أنّ خطأ التدريب **متفائل** دائماً. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.30): تصنيف البريد المزعج — الخطر هو معدّل الخطأ المعطيات: 10,000 رسالة موسومة؛ خسارة 0-1: $\ell = 1$ عند الخطأ وإلا 0. المطلوب: صيغة الخطر وقراءته. الحل: الخطوة 1: $R(h) = \mathbb{P}_{(x,y)\sim\mathcal{D}}[h(x) \neq y]$. الخطوة 2: $\hat{R}_S(h) = \frac{1}{n}\sum_i \mathbf{1}[h(x_i) \neq y_i]$ = نسبة أخطاء التدريب. الخطوة 3: الهدف ليس صفراً على التدريب بل الصغر على $\mathcal{D}$. النتيجة: الخطر «معدّل خطأ مستقبلي»، والخطر التجريبي «معدّل خطأ ماضي». الربط بالذكاء الاصطناعي: هذا التعريف هو ما تقيسه مجموعة الاختبار تقريباً، لا ما يقيسه التدريب.

مثال (30.2-2): التشخيص الطبي — خسارة غير متماثلة المعطيات: كشف مرض، تكلفة الخطأ السلبي الكاذب (FN) = 100 وحدة، والإيجابي الكاذب (FP) = 1. المطلوب: دالّة الخسارة والخطر. الحل: الخطوة 1: ℓ مصفوفة تكلفة: $\ell(\hat{y}=0,y=1)=100$، $\ell(\hat{y}=1,y=0)=1$. الخطوة 2: $R(h)=100\,\mathbb{P}[FN]+1\,\mathbb{P}[FP]$. الخطوة 3: تقليل الخطر $\neq$ تقليل معدّل الخطأ هنا. النتيجة: المصنّف الأمثل يميل للحساسية العالية بدل العتبة المعتادة 0.5. الربط بالذكاء الاصطناعي: العتبة المثلى هنا: صنّف إيجاباً إذا $\mathbb{P}(y=1|x)>\frac{1}{100+1}\approx 0.0099$.

مثال (30.2-3): التنبؤ المالي — الخسارة التربيعية المعطيات: تنبؤ بعائد سهم، $\ell(\hat{y},y)=(\hat{y}-y)^2$. المطلوب: الخطر وتفكيكه. الحل: الخطوة 1: $R(h)=\mathbb{E}[(h(X)-Y)^2]$. الخطوة 2: بأفضل تنبؤ ممكن $h^\star(x)=\mathbb{E}[Y|x]\Rightarrow R^\star=\mathbb{E}[\mathrm{Var}(Y|x)]$ (ضجيج السوق). الخطوة 3: $R-R^\star=\mathbb{E}[(h-h^\star)^2]$. النتيجة: كلّ ما يمكن فعله هو تقليل البعد عن «القيمة المتوقّعة الحقيقية». الربط بالذكاء الاصطناعي: لا نموذج يتفوّق على انحراف السوق نفسه.

مثال (30.2-4): بناء محفظة استثمارية المعطيات: خسارة = سالب العائد المعدّل بالمخاطر. المطلوب: صياغة الخطر. الحل: الخطوة 1: $\ell(h(x),y)=-(\text{عائد})+c\,(\text{تقلّب})$. الخطوة 2: R = العائد المتوقّع سالباً عقاب التقلّب. النتيجة: إطار التعلّم يستوعب أهدافاً مالية مركّبة. الربط بالذكاء الاصطناعي: يربط هذا الفصل بمسائل التحسين المالي (الفصل 25).

مثال (30.2-5): كشف التسلّل الشبكي ببيانات شديدة الاختلال المعطيات: 0.1% هجمات، 99.9% حركة سليمة. المطلوب: خطر مصنّف «يتوقّع السلامة دائماً». الحل: الخطوة 1: $\hat{R}_S=0.001$ — يبدو ممتازاً! الخطوة 2: لكنّه لا يعمّم شيئاً: استرجاع (recall) = صفر. النتيجة: الخطر وحده مضلّل تحت الاختلال، أضف مقاييس أو أعد توازن الخسارة. الربط بالذكاء الاصطناعي: سبب استخدام F_1 و PR-AUC في الأمن السيبراني.

مثال (30.2-6): الترجمة الآلية — خسارة على مستوى السلسلة المعطيات: $\mathcal{Y}$ = فضاء الجُمل، $\ell=1-\mathrm{BLEU}$. المطلوب: لماذا يصعب تقليل الخطر مباشرة؟ الحل: الخطوة 1: $\mathcal{Y}$ ضخم $\Rightarrow$ لا يمكن عدّ الأخطاء بـ 0-1 بسيطة. الخطوة 2: نتعلّم بمعيار بديل (إنتروبيا تقاطعية على الرموز). النتيجة: الخسارة البديلة تُقلَّل، والخطر الحقيقي يُؤمَل أن يتبعها. الربط بالذكاء الاصطناعي: الفجوة بين خسارة التدريب ومقياس التقييم مشكلة معروفة في NLP (سيُفصّل في الفصل 39).

مثال (30.2-7): القيادة الذاتية وانزياح التوزيع المعطيات: تدريب في مدينة مشمسة، تشغيل تحت المطر. المطلوب: هل يكفي تقليل $\hat{R}_S$؟ الحل: الخطوة 1: الخطر يُعرَّف تحت $\mathcal{D}$ التدريب، والتشغيل تحت $\mathcal{D}'$ مختلفة. الخطوة 2: الحدود المضمونة تفترض $\mathcal{D}=\mathcal{D}'$. النتيجة: إطار التعلّم i.i.d. لا يغطّي انزياح التوزيع (domain shfit). الربط بالذكاء الاصطناعي: حقل «التعميم خارج التوزيع» (OOD) برمته نابع من هذا القصور الافتراضي.

مثال (30.2-8): التسعير الديناميكي المعطيات: $\ell=$ الإيراد الضائع مقارنةً بالسعر الأمثل المجهول. المطلوب: صياغة التعلّم. الحل: الخطوة 1: الخسارة تعتمد على y = استجابة العميل المجهولة. الخطوة 2: تقليل $\hat{R}$ = تقليل ندم (regret) ملاحظ. النتيجة: يصير التعلّم مسألة «تعلّم بالاستكشاف» لا تصنيفاً. الربط بالذكاء الاصطناعي: يربط الفصل بنظرية bandits والفصل 44.

مثال (30.2-9): التوصية وخسارة الترتيب المعطيات: $\mathcal{Y}$ = ترتيب عناصر، ℓ = خسارة ترتيب (pairwise). المطلوب: الخطر. الحل: الخطوة 1: $\ell=\sum_{(i,j):y_i>y_j}\mathbf{1}[h(x)_i<h(x)_j]$. الخطوة 2: R = نسبة الأزواج المقلوبة متوقّعةً. النتيجة: الخسائر غير المتحلّلة شائعة وتستلزم بدائل قابلة للتحسين. الربط بالذكاء الاصطناعي: الخسائر البديلة المحدّبة (surrogate) هي الحلّ العملي.

مثال (30.2-10): الرؤية الحاسوبية — الإنتروبيا التقاطعية بديلاً عن 0-1 المعطيات: تصنيف 1000 صنف، نُدرّب على CE من الفصل 27. المطلوب: العلاقة بالخطر الحقيقي. الحل: الخطوة 1: الخطر الحقيقي بمقياس 0-1 غير قابل للتحسين المباشر (غير متصل). الخطوة 2: CE حدٌّ أعلاه متّصل، تقليلها يقلّل خطأ 0-1 عادةً. النتيجة: نضحّي بالمطابقة التامّة مقابل قابلية التحسين. الربط بالذكاء الاصطناعي: «الخسارة البديلة المتوافقة» (consistent surrogate) موضوع

بحثي قائم.

مثال (30.2-11): الروبوتات — خطر على مسار كامل المعطيات: سياسة تتحكّم بذراع، الخسارة على المسار كلّه. المطلوب: الفرق عن التعلّم المراقَب. الحل: الخطوة 1: $R = \mathbb{E}_{\text{مسار}}[\sum_t \ell(s_t, a_t)]$. الخطوة 2: اختيار الفعل يغيّر توزيع الحالات $\Rightarrow$ ليست i.i.d. النتيجة: الإطار يحتاج تعميماً (عمليات ماركوف للقرار، الفصل 44). الربط بالذكاء الاصطناعي: لهذا لا تُطبَّق حدود هذا الفصل على RL مباشرة.

مثال (30.2-12): ضجيج التسميات يرفع خطر بايز المعطيات: 10% من التسميات مقلوبة عشوائياً؛ الحقيقة حتمية. المطلوب: $R^\star$. الحل: الخطوة 1: حتى لو كانت العلاقة الحتمية في الأصل، فإنّ $\mathbb{P}(y|x)$ باتت عشوائية بسبب الضجيج. الخطوة 2: $R^\star \geq 0.1$ (لا يمكن تجاوز نسبة الضجيج). النتيجة: سقف أداء لا يُكسر مهما كبر النموذج. الربط بالذكاء الاصطناعي: تنظيف البيانات أهمّ أحياناً من تكبير النموذج.

مثال (30.2-13): حساب مصنّف بايز وخطره المعطيات: $\mathbb{P}(y=1|x) = 0.8$ عند $x = a$ و 0.3 عند $x = b$، باحتمالين متساويين. المطلوب: $h^\star$ و $R^\star$. الحل: الخطوة 1: $h^\star(a) = 1$، $h^\star(b) = 0$. الخطوة 2: $R^\star = \frac{1}{2}(0.2) + \frac{1}{2}(0.3) = 0.25$. النتيجة: ربع الحالات تُخطئها أفضل فرضية ممكنة. الربط بالذكاء الاصطناعي: معيار واقعي لأيّ نموذج: كم تبقّى إلى $R^\star$؟

مثال (30.2-14): تنفيذ ERM على فضاء فرضيات منتهٍ المعطيات: $\mathcal{H} = \{h_1, h_2, h_3\}$، أخطاء التدريب على $n = 10$: $2, 5, 9$ أخطاء. المطلوب: مخرجات ERM وخطرها التجريبي. الحل: الخطوة 1: $\hat{R}(h_1) = 0.2$، $\hat{R}(h_2) = 0.5$، $\hat{R}(h_3) = 0.9$. الخطوة 2: $\hat{h} = h_1$. النتيجة: ERM لا يعرف شيئاً عن التعميم؛ يختار الأصغر على التدريب فقط. الربط بالذكاء الاصطناعي: لذلك نحتاج حدوداً تربط $\hat{R}$ بـ R (النظرية 30.3).

مثال (30.2-15): تفكيك الخطر الزائد على الورق المعطيات: $R^\star = 0.05$، $R(\hat{h}) = \inf_{h\in\mathcal{H}} R(h) = 0.12$، 0.18. المطلوب: تفكيك (30.5). الحل: الخطوة 1: خطأ التقريب $0.12 - 0.05 = 0.07$. الخطوة 2: خطأ التقدير $0.18 - 0.12 = 0.06$. الخطوة 3: المجموع $R(\hat{h}) - R^\star = 0.13$ ✓. النتيجة: تشخيص فوري: هل نكبّر النموذج أم نزيد البيانات؟ الربط بالذكاء الاصطناعي: هذه هي خريطة التشخيص التي تُبنى عليها منحنيات التعلّم (30.8).

أخطاء شائعة

- تقييم النموذج على بيانات التدريب والظنّ أنّه «تعميم» (الخطر التجريبي متحيّز للأسفل).
- نسيان أنّ $\hat{h}$ تعتمد على $S \Rightarrow$ لا يجوز تطبيق قانون الأعداد الكبرى عليها.
- استخدام خسارة 0-1 ثمّ الشكوى من عدم قابليتها للتحسين.
- تجاهل $R^\star$: مطالبة النموذج بأداء أفضل من حدّ الضجيج.
- افتراض i.i.d. في مسائل متسلسلة زمنيّاً أو تفاعلية (RL).

المبرهنة (تقارب موحّد لفضاء منتهٍ): لتكن $\mathcal{H}$ منتهية و ℓ محصورة في $[0,1]$. لكلّ $\delta \in (0,1)$، باحتمال $\geq 1-\delta$ على سحب $S \sim \mathcal{D}^n$، **لكلّ** $h \in \mathcal{H}$ معاً:

$$\left|R(h) - \hat{R}_S(h)\right| \;\leq\; \varepsilon(n, |\mathcal{H}|, \delta) \;=\; \sqrt{\frac{\ln(2|\mathcal{H}|/\delta)}{2n}} \tag{30.6}$$

وبالتالي لفرضية ERM (بل لأيّ h تختاره بعد رؤية S):

$$R(\hat{h}) \;\le\; \hat{R}_S(\hat{h}) \;+\; \sqrt{\frac{\ln\!\big(2|\mathcal{H}|/\delta\big)}{2n}} \tag{7.30}$$

مبدأ SRM (فابنيك): لتكن $\mathcal{H}_1 \subset \mathcal{H}_2 \subset \cdots$ سلسلةً متزايدة من فضاءات الفرضيات بعقوبات سعة $\Omega(\mathcal{H}_k, n, \delta)$ متزايدة في k. يختار المرء

$$\hat{k} \;=\; \arg\min_{k} \Big[\min_{h \in \mathcal{H}_k} \hat{R}_S(h) \;+\; \Omega(\mathcal{H}_k, n, \delta) \Big], \qquad \hat{h} = \arg\min_{h \in \mathcal{H}_{\hat{k}}} \hat{R}_S(h) \tag{8.30}$$

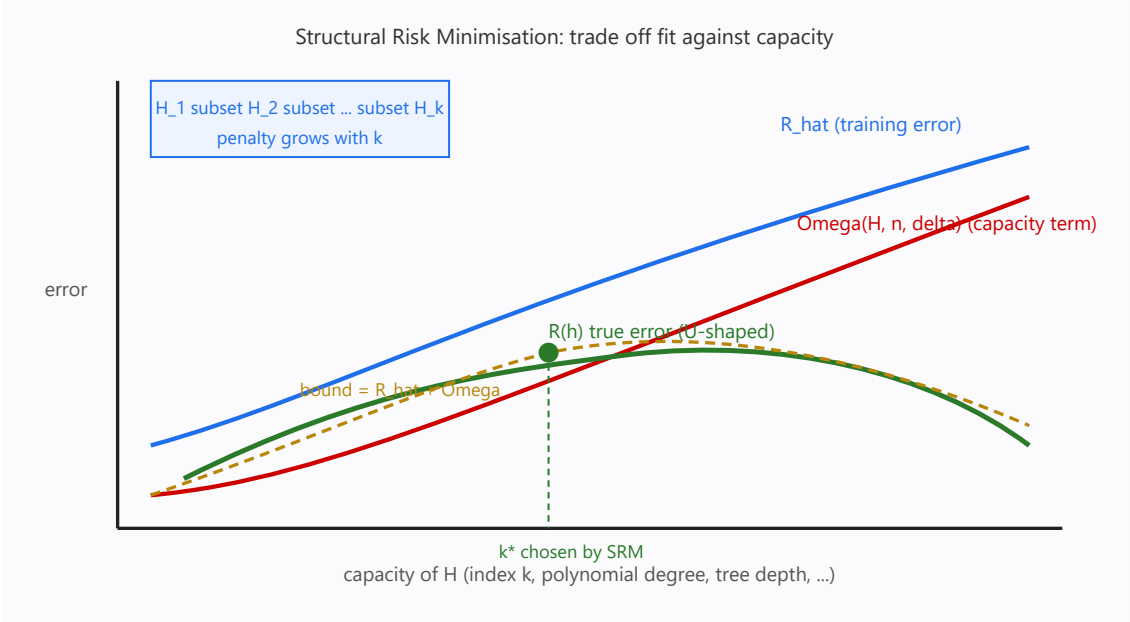
فينال الحدّ $R(\hat{h}) \le \min_k \left[\hat{R}_k + \Omega_k\right]$ باحتمال $1-\delta$.

جدول الرموز

الرمز	المعنى	ملاحظة
ε	شبه طوق التقارب الموحّد	$\propto \sqrt{\ln\|\mathcal{H}\|/n}$
bound union	اتّحاد الاحتمالات	يعطي معامل $\ln\|\mathcal{H}\|$
هوفدينغ $\widetilde{\Omega}(\mathcal{H}_k)$	متراجحة التركيز (الفصل 17)	لمتغيّرات محدودة
عقاب السعة		يكبر مع k
$1-\delta$	ثقة الحدّ	$\delta = 0.05$ شائع
تقارب موحّد	$\sup_{h\in\mathcal{H}} \lvert\cdot\rvert \to 0$	الشرط المركزي

الرسم

<figure> الشكل<figcaption> 2.30: الخطر التجريبي يهبط مع السعة وعقاب السعة يرتفع؛ المحصّلة منحنىً على شكل



شكل ٢.٣٠: *
مبدأ تقليل الخطر البنيوي

U، وتختار SRM قاعه.<figcaption/> </figure>

البرهان

الخطوة 1 (هوفدينغ لفرضية ثابتة): لكلّ h ثابت، المتغيّرات $\ell(h(x_i), y_i) \in [0,1]$ مستقلّة بمتوسط $R(h)$ $\Rightarrow$ بمتراجحة هوفدينغ (الفصل 17): $\mathbb{P}[|\hat{R}(h) - R(h)| > \varepsilon] \le 2e^{-2n\varepsilon^2}$.

الخطوة 2 (اتّحاد على $\mathcal{H}$):

$$\mathbb{P}\Big[\exists h \in \mathcal{H} : \ |\hat{R}(h) - R(h)| > \varepsilon\Big] \ \le \ \sum_{h \in \mathcal{H}} 2e^{-2n\varepsilon^2} \ = \ 2|\mathcal{H}|e^{-2n\varepsilon^2}$$

الخطوة 3 (الحلّ لـ ε): نطلب $2|\mathcal{H}|e^{-2n\varepsilon^2} = \delta$ $\Rightarrow$ $\varepsilon^2 = \frac{\ln(2|\mathcal{H}|/\delta)}{2n}$ $\Rightarrow$ (6.30). ■

الخطوة 4 (حدّ ERM): لأنّ الحدّ يصحّ **لكلّ** h معاً، فهو يصحّ خصوصاً لـ $\hat{h}$ المختارة بعد رؤية S $\Rightarrow$ (7.30).

الخطوة 5 (SRM): بتطبيق اتّحاد على كلّ الفضاءات مع أوزان $\delta_k = \delta/2^k$ (أو تقسيم متساوٍ)، تصحّ كلّ الحدود معاً باحتمال $1-\delta$ $\Rightarrow$ اختيار k بالحدّ (لا بالخطر التجريبي وحده) يعطي أصغر حدّ متاح. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.30): حدّ أساسي لفضاء من 1000 فرضية المعطيات: $|\mathcal{H}| = 1000$، $n = 1000$، $\delta = 0.05$. المطلوب: هامش التعميم ε. الحل: الخطوة 1: $\ln(2 \times 1000/0.05) = \ln(40000) = 10.597$. الخطوة 2: $\varepsilon = \sqrt{10.597/2000} = \sqrt{0.005298} = 0.0728$. النتيجة: بثقة 95%، خطر التعميم لا يتجاوز خطأ التدريب بأكثر من 7.3 نقطة. الربط بالذكاء الاصطناعي: أثر «فجوة التعميم» الذي نقيسه عملياً بين التدريب والاختبار.

مثال (2-3.30): أثر مضاعفة البيانات 100 مرّة المعطيات: نفس $|\mathcal{H}|$، $n = 100{,}000$. المطلوب: ε. الحل: الخطوة 1: $\sqrt{10.597/200000} = \sqrt{5.298 \times 10^{-5}} = 0.00728$. ε. النتيجة: تقلّص الهامش من 3.7% إلى 0.73% — تحسّن بـ $\sqrt{100} = 10$ مرّات. الربط بالذكاء الاصطناعي: معدّل $1/\sqrt{n}$ هو سبب الاندفاع نحو مجموعات بيانات ضخمة.

مثال (3-3.30): أثر حجم فضاء الفرضيات المعطيات: $|\mathcal{H}| = 10^6$، $n = 1000$، $\delta = 0.05$. المطلوب: ε. الحل: الخطوة 1: $\ln(2 \times 10^6/0.05) = \ln(4 \times 10^7) = 17.504$. الخطوة 2: $\varepsilon = \sqrt{17.504/2000} = \sqrt{0.008752} = 0.0936$. النتيجة: مضاعفة السعة بألف مرّة كلّفت 2 نقطة مئوية فقط. الربط بالذكاء الاصطناعي: أثر السعة **لوغاريتمي** — وهذا أحد أسرار نجاح النماذج الضخمة.

مثال (4-3.30): أثر مستوى الثقة المعطيات: $|\mathcal{H}| = 1000$، $n = 1000$، $\delta = 0.01$ بدل 0.05. المطلوب: ε. الحل: الخطوة 1: $\ln(2 \times 1000/0.01) = \ln(200000) = 12.206$. الخطوة 2: $\varepsilon = \sqrt{12.206/2000} = 0.0781$. النتيجة: تشديد الثقة من 95% إلى 99% كلّف 5.0 نقطة فقط. الربط بالذكاء الاصطناعي: الحدود رخيصة الثمن في δ وباهظة في n.

مثال (5-3.30): تعقيد العيّنة المطلوب المعطيات: نريد $\varepsilon = 0.01$ مع $|\mathcal{H}| = 1000$، $\delta = 0.05$. المطلوب: n. الحل: الخطوة 1: $\frac{\ln(2|\mathcal{H}|/\delta)}{2\varepsilon^2} = \frac{10.597}{2\times 10^{-4}}$. الخطوة 2: $n \ge 52{,}983$. النتيجة: نحو 53 ألف عيّنة لضمان هامش 1%. الربط بالذكاء الاصطناعي: قاعدة عملية: التحسين بمعامل 10 في الدقّة يكلّف 100 ضعف البيانات.

مثال (6-3.30): اقتصاد اللوغاريتم المعطيات: $|\mathcal{H}|$ من 1000 إلى 2000، $n = 1000$. المطلوب: تغيّر ε. الحل: الخطوة 1: $\ln(80000) = 11.290 \Rightarrow \varepsilon = 0.0751$. الخطوة 2: النسبة $0.0751/0.0728 = 1.032$. النتيجة: مضاعفة السعة $\Rightarrow$ +3.2% فقط في الهامش. الربط بالذكاء الاصطناعي: تبرير أوّلي لتفضيل النماذج الكبيرة مع بيانات كافية.

مثال (7-3.30): SRM عملياً — ثلاث فضاءات المعطيات: $\mathcal{H}_1, \mathcal{H}_2, \mathcal{H}_3$ على $\hat{R}$؛ العقوبات $\Omega = 0.02, 0.06, 0.15$. المطلوب: أيّ فضاء نختار؟ الحل: الخطوة 1: الحدود: $0.25, 0.26, 0.32$.

الخطوة 2: الأصغر هو $\mathcal{H}_3$ بـ 0.25. النتيجة: SRM قد يفضّل الأكبر إذا تحسّن الملاءمة بما يبرّر العقاب. الربط بالذكاء الاصطناعي: ليس «الأبسط دائماً» بل «أفضل حدّ مضمون».

مثال (30.3-8): درجة كثيرة الحدود المعطيات: $n = 50$، درجات $1, 3, 9$ بأخطاء تدريب $0.22, 0.06, 0.001$ وعقوبات $0.08, 0.18, 0.45$. المطلوب: الدرجة المثلى بـ SRM. الحل: الخطوة 1: الحدود: $0.30, 0.24, 0.451$. الخطوة 2: الأصغر = الدرجة 3. النتيجة: الدرجة 9 تفرط في الملاءمة رغم خطأ تدريب شبه معدوم. الربط بالذكاء الاصطناعي: المثال الكلاسيكي للإفراط في الملاءمة محسوباً لا مرسوماً.

مثال (30.3-9): عمق شجرة القرار المعطيات: أعماق $1 \dots 6$ بأخطاء $0.35, 0.25, 0.18, 0.12, 0.06, 0.01$ وعقوبات $0.03, 0.06, 0.10, 0.15, 0.22, 0.32$. المطلوب: العمق الأمثل. الحل: الخطوة 1: الحدود: $0.38, 0.31, 0.28, 0.27, 0.28, 0.33$. الخطوة 2: الأصغر عند العمق 4 (0.27). النتيجة: العمق 5 و 6 يخسران رغم تحسّن التدريب. الربط بالذكاء الاصطناعي: هذا هو جوهر «تقليم» الأشجار (pruning) theoretically.

مثال (30.3-10): عرض شبكة عصبية المعطيات: ثلاث شبكات (16، 256، 4096 وحدة مخفية) بأخطاء تدريب $0.18, 0.05, 0.001$ وعقوبات $0.10, 0.25, 0.55$. المطلوب: أيّ شبكة بـ SRM؟ الحل: الخطوة 1: الحدود: $0.28, 0.30, 0.551$. الخطوة 2: الأصغر = الشبكة الصغيرة (16). النتيجة: عكس مثال 30.3-7: هنا لم يبرّر تحسّن التدريب تكلفة السعة. الربط بالذكاء الاصطناعي: يفسّر نجاح ضغط النماذج وتقليمها في الأجهزة الطرفية.

مثال (30.3-11): لماذا لا نختار أكبر فضاء دائماً؟ المعطيات: $\mathcal{H}$ لانهائي (مثل كلّ الدوالّ القابلة للقياس). المطلوب: ماذا يحدث للحدّ؟ الحل: الخطوة 1: $|\mathcal{H}| = \infty \Rightarrow \ln|\mathcal{H}|$ الحدّ (30.6) لا معنى له. الخطوة 2: الحقيقة أسوأ: يمكن لـ ERM أن يحفظ العيّنة (R التدريبي $= 0$) ويخفق كلّياً في التعميم. النتيجة: السعة اللانهائية بلا عقاب = لا ضمان إطلاقاً. الربط بالذكاء الاصطناعي: هذه هي الفجوة التي يملؤها **بُعد VC** في الفصل 31.

مثال (30.3-12): حدّ مجموعة الاختبار المعطيات: $m = 10{,}000$ عيّنة اختبار، $\delta = 0.05$، الفرضية ثابتة قبل رؤية الاختبار. المطلوب: دقّة التقدير. الحل: الخطوة 1: $\varepsilon = \sqrt{\ln(2/0.05)/(2 \times 10000)} = \sqrt{3.689/20000} = 0.0136$. النتيجة: هامش $\pm 1.36\% \approx$ فقط. الربط بالذكاء الاصطناعي: حجم مجموعة الاختبار يحدّد دقّة أيّ تقرير أداء.

مثال (30.3-13): فترة ثقة لدقّة مُبلَّغة المعطيات: دقّة 92% على 1000 عيّنة اختبار، $\delta = 0.05$. المطلوب: فترة الثقة. الحل: الخطوة 1: $0.0430 = \sqrt{0.001845} = \sqrt{3.689/2000} = \varepsilon$. الخطوة 2: الفترة $[87.7\%, 96.3\%]$. النتيجة: «92%» تعني في الحقيقة «بين 88% و 96%». الربط بالذكاء الاصطناعي: أوراق كثيرة تقارن نماذج داخل هامش الخطأ نفسه!

مثال (30.3-14): تعقيد العيّنة للأحداث النادرة المعطيات: نريد $\varepsilon = 0.001$ مع $|\mathcal{H}| = 10^4$، $\delta = 0.05$. المطلوب: n. الحل: الخطوة 1: $\ln(2 \times 10^4/0.05) = \ln(4 \times 10^5) = 12.899$. الخطوة 2: $n = 12.899/(2 \times 10^{-6}) = 6.45 \times 10^6$. النتيجة: ملايين العيّنات لضمان هامش واحد بالألف. الربط بالذكاء الاصطناعي: التطبيقات الطبية والأمنية تحتاج تصميماً مختلفاً (لا مجرّد «المزيد من البيانات»).

مثال (30.3-15): الاختلال يعاقب العيّنة الفعّالة المعطيات: 0.1% هجمات، نريد 100 هجمة موسومة على الأقل. المطلوب: حجم العيّنة. الحل: الخطوة 1: $n \times 0.001 \geq 100 \Rightarrow n \geq 100{,}000$. الخطوة 2: الحدود الرسمية تعتمد على n الكلّي، لكنّ التعلّم الفعّال يعتمد على نسبة الفئة النادرة. النتيجة: «حجم العيّنة الفعّال» في الاختلال $\approx$ عدد أمثلة الفئة النادرة. الربط بالذكاء الاصطناعي: تبرير طبقات العيّنة (stratfication) وأخذ العيّنات المتوازنة.

أخطاء شائعة

- استخدام الحدود بعد اختيار النموذج على نفس البيانات (يكسر افتراض «قبل رؤية S»).

- الخلط بين ε (فرق الخطرين) وبين دقّة النموذج.
- تطبيق (6.30) على فضاء غير منتهٍ بلا تعويض $\ln|\mathcal{H}|$ ببُعد VC (الفصل 31).
- نسيان شرط حصر الخسارة في $[0,1]$ قبل استخدام هوفدينغ.
- قراءة الحدود بوصفها تقديراً دقيقاً: هي **حدود عليا متحفّظة**، والأداء الفعلي أفضل غالباً.

المبرهنة: في مسألة انحدار بقيمة حقيقية مع خسارة تربيعية و $y = f(x) + \varepsilon$ حيث $\mathbb{E}[\varepsilon] = 0$، $\mathrm{Var}(\varepsilon) = \sigma^2$ مستقلّ عن x، فإنّ الخطر المتوقّع على تكرار سحب العيّنات يتفكّك عند كلّ نقطة x:

$$\mathbb{E}_S\Big[\big(h_S(x) - f(x)\big)^2\Big] \;=\; \underbrace{\big(\bar{h}(x) - f(x)\big)^2}_{\text{Bias}^2} \;+\; \underbrace{\mathbb{E}_S\Big[\big(h_S(x) - \bar{h}(x)\big)^2\Big]}_{\text{Variance}} \;+\; \sigma^2 \tag{9.30}$$

$$\bar{h}(x) \;=\; \mathbb{E}_S\big[h_S(x)\big] \tag{10.30}$$

والخطر الكلي $R(h_S) = \mathbb{E}_x[\cdot] + \sigma^2$. التحيز يقلّ بتوسيع $\mathcal{H}$ والتباين يزيد؛ ونقطة التوازن هي «السعة المثلى».

جدول الرموز

الرمز	المعنى	ملاحظة
$f(x)$	الدالّة الحقيقية (القيمة المتوقّعة)	مجهولة
$\bar{h}$	متوسط الفرضيات على كلّ العيّنات الممكنة	«النموذج المتوسّط»
Bias^2	مربع انحراف المتوسط عن الحقيقة	قصور النموذج
Variance	حساسية الفرضية للعيّنة	قصور البيانات
σ^2	تباين الضجيج	غير قابل للتقليل
$\mathbb{E}_S$	التوقّع على تكرار سحب S	لا على نقطة واحدة

الرسم

<figure> الشكل<figcaption> 3.30: لوحة السهام: مركز اللوحة هو الهدف $f(x)$، والنقاط هي تنبؤات h_S لعيّنات تدريب مختلفة؛ التحيز = بُعد المجموعة عن المركز، التباين = تشتّتها.</figcaption> </figure>

<figure> الشكل<figcaption> 4.30: مع زيادة السعة يهبط التحيز ويرتفع التباين، فيتولّد منحنى الخطر على شكل U مع خطّ أرضيّ عند σ^2.</figcaption> </figure>

البرهان

الخطوة 1 (إضافة وطرح): $h_S - f = (h_S - \bar{h}) + (\bar{h} - f)$.

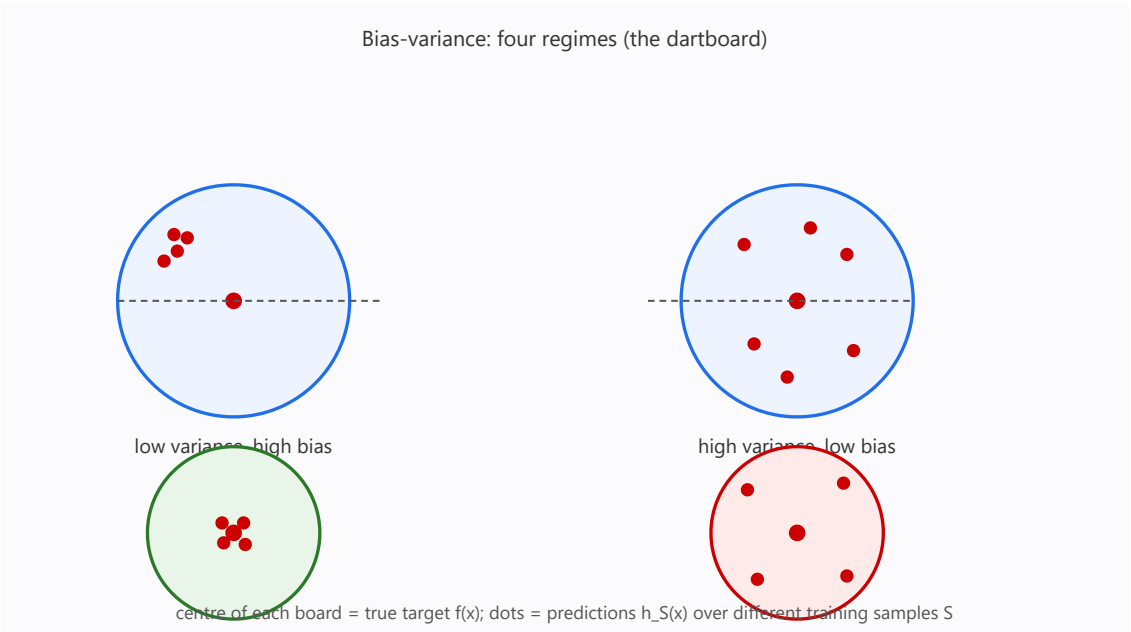
الخطوة 2 (التربيع والأخذ بالتوقّع):

$$\mathbb{E}[(h_S - f)^2] = \mathbb{E}[(h_S - \bar{h})^2] + 2\,\mathbb{E}[(h_S - \bar{h})](\bar{h} - f) + (\bar{h} - f)^2$$

والحدّ الأوسط صفر لأنّ $\mathbb{E}_S[h_S - \bar{h}] = 0 \Rightarrow$ نحصل على التحيز^2 + التباين.

الخطوة 3 (الضجيج): الخطر الكامل هو $\mathbb{E}_{x,y}[(h_S(x) - y)^2]$، وبكتابة $y = f(x) + \varepsilon$ مع $\varepsilon \perp x$:

$$\mathbb{E}[(h_S - y)^2] = \mathbb{E}[(h_S - f)^2] - 2\mathbb{E}[(h_S - f)\varepsilon] + \mathbb{E}[\varepsilon^2]$$



شكل ٣٠.٣٠: *
لوحة السهام للتحيز والتباين

والحدّ الأوسط صفر ⇒ يضاف σ^2. ■

الخطوة 4 (حدسيّاً): التحيز = «هل يستطيع النموذج تمثيل الحقيقة؟»، التباين = «هل يستطيع البيانات تحديد النموذج؟».

الخطوة 5 (تنبيه): التفكيك (9.30) حرفيٌّ للخسارة التربيعية؛ لخسارة 0-1 توجد صيغ مشابهة لكن بسلوك مختلف (المثال 14-4.30). ■

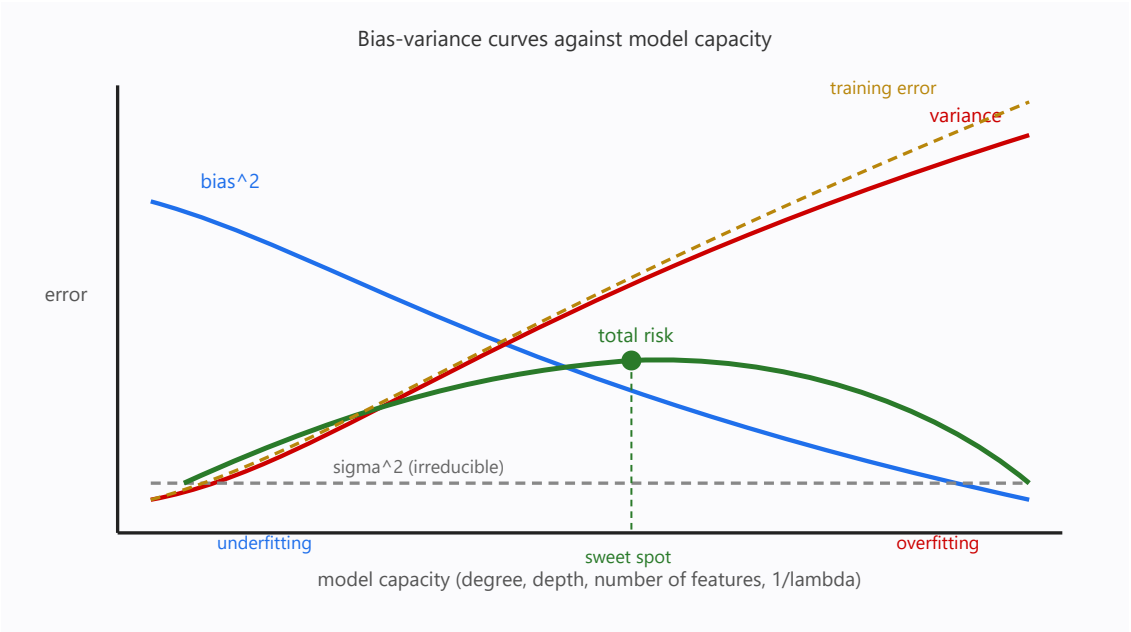
خمسة عشر مثالاً محلولاً

مثال (1-4.30): حصيلة رقمية للتفكيك المعطيات: $\text{Bias}^2 = 4$، $\text{Variance} = 1$، $\sigma^2 = 2$. المطلوب: الخطر. الحل: الخطوة 1: $R = 4 + 1 + 2 = 7$. الخطوة 2: أفضل خطر ممكن $= 2$ (لو كان النموذج مثاليّاً). النتيجة: 5 وحدات من أصل 7 قابلة للتقليل؛ 4 منها بالتحيز. الربط بالذكاء الاصطناعي: التشخيص يبدأ بمعرفة أيّ الحدّين يهيمن.

مثال (2-4.30): أقرب الجيران ومعامل k المعطيات: $k = 1$ مقابل $k = 25$ على نفس البيانات. المطلوب: المقارنة. الحل: الخطوة 1: $k = 1$: تحيز منخفض (يتبع البيانات بدقّة)، تباين عالٍ (يتغيّر بتغيّر نقطة واحدة). الخطوة 2: $k = 25$: تحيز أعلى (يمهّد الحدود)، تباين منخفض. النتيجة: k هو مقبض التحيز–التباين الصريح في هذه الخوارزمية. الربط بالذكاء الاصطناعي: اختيار k بالتحقق المتقاطع هو اختيار نقطة التوازن.

مثال (3-4.30): تباين الانحدار الخطي يكبر مع البعد المعطيات: $\sigma^2 = 1$، $n = 200$، مرّتان: $d = 10$ ثمّ $d = 100$. المطلوب: التباين التقريبي. الحل: الخطوة 1: للانحدار الخطي المتعامد: $\text{Var} \approx \sigma^2 d/n$. الخطوة 2: $d = 10$: $10/200 = 0.05$؛ $d = 100$: $100/200 = 0.5$. النتيجة: عشرة أضعاف الخصائص ⇒ عشرة أضعاف التباين. الربط بالذكاء الاصطناعي: «لعنة الأبعاد» في صيغتها الإحصائية البسيطة.

مثال (4-4.30): الحيد (ridge) يبدّل تحيزاً بتباين — بالأرقام المعطيات: تصميم متعامد بقيمة ذاتية $s = 1$ للمتغيّر، $\sigma^2 = 1$، معلمة حقيقية $\theta = 1$، $\lambda = 0.5$. المطلوب: خطر الحيد مقابل المربّعات الصغرى. الحل: الخطوة 1: بدون تنظيم: $\text{Var} = \sigma^2/s = 1$، $\text{Bias}^2 = 0 \Rightarrow$ الخطر $= 1$. الخطوة 2: مع الحيد: $\text{Var} = \sigma^2 s/(s+\lambda)^2 = 1/2.25 = 0.444$. الخطوة 3: $\text{Bias}^2 = \lambda^2\theta^2/(s+\lambda)^2 = (0.25)(1)/2.25 = 0.111$. الخطوة 4: الخطر



شكل ٣٠.٤: *
منحنيات التحيز والتباين

$0.556 = 0.444 + 0.111$ =. النتيجة: خفضنا الخطر بنحو 44% بدفع قليل من التحيز. الربط بالذكاء الاصطناعي: هذه هي الحِكمة الكمّية وراء التنظيم المنتشر في كلّ مكان.

مثال (30.4-5): التجميع (bagging) يقلّل التباين المعطيات: 10 نماذج مستقلّة، تباين كلّ منها $\sigma_h^2 = 0.9$ وتحيز^2 0.1 =. المطلوب: خطر المتوسط. الحل: الخطوة 1: تباين المتوسط $0.09 = 0.9/10$ =. الخطوة 2: التحيز لا يتغيّر 0.1 =. الخطوة 3: الخطر $0.19 =$ مقابل 1.0 للنموذج الواحد. النتيجة: التجميع يهاجم التباين فقط. الربط بالذكاء الاصطناعي: سبب فعاليّة Forest Random ونجاح ensemblingعامّةً.

مثال (30.4-6): أثر عدد النماذج في التجميع المعطيات: تباين النموذج الواحد 0.5، نريد تبايناً < 0.02. المطلوب: عدد النماذج (باستقلال تامّ). الحل: الخطوة 1: $0.5/M < 0.02 \Rightarrow M > 25$. النتيجة: عوائد متناقصة: من $M = 25$ إلى 250 نكسب 0.018 فقط. الربط بالذكاء الاصطناعي: يبرّر الاكتفاء بـ 10–50 نموذجاً في معظم التطبيقات.

مثال (30.4-7): صيغة تباين الغابة العشوائية مع الارتباط المعطيات: $M = 100$ أشجار، تباين الشجرة $\sigma^2 = 1$، ارتباط الأزواج $\rho = 0.3$. المطلوب: تباين المتوسط. الحل: الخطوة 1: $\text{Var} = \rho\sigma^2 + \frac{1-\rho}{M}\sigma^2 = 0.3 + 0.007 = 0.307$. النتيجة: الارتباط يضع حدّاً أدنى للتباين لا يمكن تجاوزه (0.3 هنا). الربط بالذكاء الاصطناعي: هذا يبرّر الاختيار العشوائي للخصائص في Forest: Random خفض ρ.

مثال (30.4-8): تحيز سوء تحديد النموذج بالأرقام المعطيات: الحقيقة $f(x) = x^2$ على $x \sim \mathcal{U}[-1, 1]$، نقترب بخطّ مستقيم. المطلوب: أدنى تحيز^2 ممكن. الحل: الخطوة 1: بالتماثل الميل صفر والثابت $a = \mathbb{E}[x^2] = 1/3$. الخطوة 2: $\mathbb{E}[(x^2 - \frac{1}{3})^2] = \mathbb{E}[x^4] - \frac{2}{3}\mathbb{E}[x^2] + \frac{1}{9} = \frac{1}{5} - \frac{2}{9} + \frac{1}{9} = 0.0889$. النتيجة: أرضية تحيز 0.089 لا تزول بزيادة البيانات. الربط بالذكاء الاصطناعي: علامة التشخيص: منحنى التعلّم يستوي عند خطأ مرتفع $\Rightarrow$ زِد السعة.

مثال (30.4-9): أرضية الضجيج المعطيات: $\sigma^2 = 1$، النموذج بلغ خطأ تدريب 0.02 وخطأ اختبار 1.02. المطلوب: التفسير. الحل: الخطوة 1: الخطر الأدنى الممكن $\sigma^2 = 1$ =. الخطوة 2: النموذج بلغ 1.02 — أي قريب من المثالي. النتيجة: «خطأ اختبار مرتفع» ليس دائماً إفراطاً في الملاءمة! الربط بالذكاء الاصطناعي: قارن دائماً بأرضية

الضجيج قبل «تحسين» النموذج.

مثال (10-4.30): خبير متحيّز مقابل خبير متقلّب المعطيات: طبيبان: الأوّل يخطئ منهجيّاً بنحو 5%، والثاني يخطئ عشوائيّاً بنحو 5%. المطلوب: أيّهما أسهل تحسناً؟ الحل: الخطوة 1: الأوّل تحيز عالٍ ⇒ يحتاج نموذجاً/معلومات جديدة. الخطوة 2: الثاني تباين عالٍ ⇒ يكفيه المتوسط أو مزيد من البيانات. النتيجة: وصفة التحسين تعتمد على نوع الخطأ. الربط بالذكاء الاصطناعي: مقابلتها في :ML توسيع النموذج مقابل زيادة البيانات/التنظيم.

مثال (11-4.30): التعزيز (boosting) يهاجم التحيز أوّلاً المعطيات: أشجار ضحلة (جذوع) تُجمع تعزيزيّاً. المطلوب: لماذا تنجح؟ الحل: الخطوة 1: كلّ جذع تحيزه عالٍ وتباينه منخفض. الخطوة 2: التعزيز يقلّل التحيز تراكميّاً (يضيف مصحّحات). النتيجة: التعزيز ≠ التجميع فيما يهاجمانه. الربط بالذكاء الاصطناعي: Boosting Gradient يتفوّق حيث يهيمن التحيز، Forest Random حيث يهيمن التباين.

مثال (12-4.30): التوقّف المبكر (early stopping) المعطيات: شبكة تُدرَّب 200 دورة، خطأ التحقّق يهبط حتى الدورة 40 ثمّ يرتفع. المطلوب: التفسير بالتحيز–التباين. الحل: الخطوة 1: قبل 40: ما زال التحيز يهبط أسرع من ارتفاع التباين. الخطوة 2: بعد 40: التباين (حفظ الضجيج) يهيمن. النتيجة: التوقّف المبكر = إيقاف عند نقطة التوازن. الربط بالذكاء الاصطناعي: أبسط وأرخص مضادّ للإفراط في الملاءمة.

مثال (13-4.30): التسرب (dropout) بوصفه تجميعاً المعطيات: شبكة بنسبة تسرب 0.5. المطلوب: أثرها على التحيز والتباين. الحل: الخطوة 1: كلّ تمريرة = شبكة فرعية مختلفة ⇒ التدريب يقرُب من متوسط شبكات كثيرة. الخطوة 2: المتوسط يقلّل التباين، والتحقّق يستخدم الشبكة الكاملة (تقريب المتوسط). النتيجة: تنظيمٌ ضمنيّ يستهدف التباين. الربط بالذكاء الاصطناعي: يفسّر نجاح Dropout قبل شيوع BatchNorm.

مثال (14-4.30): تحذير — التفكيك للتصنيف ليس حرفيّاً المعطيات: تصنيف ثنائي بخسارة 0-1. المطلوب: هل ينطبق (9.30)؟ الحل: الخطوة 1: (9.30) اشتُقّ للخسارة التربيعية، لخسارة 0-1 يظهر حدّ إضافيّ يعتمد على إشارة التحيز. الخطوة 2: قد يقلّل التحيزُ (باتجاه الصنف الصحيح) الخطأ رغم «زيادة التحيز». النتيجة: استخدم (9.30) بوصفه استعارةً دقيقة في الانحدار وتقريبيّة في التصنيف. الربط بالذكاء الاصطناعي: توجد تفكيكات بديلة (Domingos) للتصنيف — لا تُعمِّم بلا تحفّظ.

مثال (15-4.30): تحقّق عددي من التفكيك المعطيات: ثلاث عيّنات أعطت تنبؤات 0.8 ,1.2 ,1.0 عند نقطة هدفها $f = 1.0$، و $\sigma^2 = 0.04$. المطلوب: التحقق من (9.30). الحل: الخطوة 1: $\bar{h} = (1.0 + 1.2 + 0.8)/3 = 1.0 \Rightarrow \text{Bias}^2 = 0$. الخطوة 2: $\text{Var} = \frac{1}{3}(0 + 0.04 + 0.04) = 0.0267$. الخطوة 3: المجموع $0.0667 = 0 + 0.0267 + 0.04$. الخطوة 4: مباشرةً: $\frac{1}{3}[(1.0-1)^2 + (1.2-1)^2 + (0.8-1)^2] + 0.04 = 0.0267 + 0.04 = 0.0667$ ✓. النتيجة: التفكيك متحقّق رقميّاً. الربط بالذكاء الاصطناعي: طريقة عملية لقياس الاثنين: درّب نماذج على عيّنات فرعية وقِس التشتّت.

أخطاء شائعة

- قول «تحيز منخفض تباين منخفض» دون تحديد السعة الممكنة (عادةً مقايضة لا منحنى مجّاني).
- تطبيق تفكيك التربيعية على خسارة 0-1 بلا تحفّظ.
- الظنّ أنّ التجميع يقلّل التحيز (هو يقلّل التباين أساساً).
- نسيان σ^2: مطالبة النموذج بما دون أرضية الضجيج.

- الخلط بين **تباين النموذج عبر العيّنات** و**تباين البيانات** و**تباين المُحسِّن العشوائي**.

المبرهنة: الصيغة المُنظَّمة لتقليل الخطر التجريبي هي

$$\min_{h \in \mathcal{H}} \; \hat{R}_S(h) \; + \; \lambda \, \Omega(h), \qquad \lambda > 0 \tag{11.30}$$

وهي مكافئة (بشروط المحدّبية والازدواج من الفصل 22) للصيغة المقيّدة $\min \hat{R}_S(h)$ s.t. $\Omega(h) \; \leq \; B$. وللانحدار الخطي $\hat{R}(w) = \frac{1}{n}\|y - Xw\|^2$:

$$\hat{w}_{\text{ridge}} \; = \; (X^\top X + \lambda I)^{-1} X^\top y \tag{12.30}$$

$$\hat{w}_{\text{lasso}} \; = \; \arg\min_{w} \frac{1}{n}\|y - Xw\|^2 + \lambda \|w\|_1 \quad \Rightarrow \quad \text{بتصميم متعامد:} \; \hat{w}_j = \operatorname{sign}(z_j)\big(|z_j| - \lambda'\big)_+ \tag{13.30}$$

والأثر على التحيز–التباين (بتصميم متعامد، قيمة ذاتية s للمتغيّر، معلمة حقيقية θ):

$$\operatorname{Var}(\hat{w}_\lambda) = \frac{\sigma^2 s}{(s+\lambda)^2}, \qquad \operatorname{Bias}^2(\hat{w}_\lambda) = \frac{\lambda^2 \theta^2}{(s+\lambda)^2} \tag{14.30}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$\Omega(h)$	معقّدية الفرضية	$\|w\|_1$، $\|w\|_2^2$، نواة، عمق
λ	قوّة التنظيم	يضبط المقايضة
$(\cdot)_+$	الجزء الموجب $\max(0, \cdot)$	يصنع التناثر
ridge	حيد L2 / Tikhonov	انكماش متّصل
lasso	L1	انتقاء متغيّرات
ازدواج	تكافؤ الصيغتين	من الفصل 22

الرسم

<figure> الشكل 5.30: منطقة القيد: الدائرة (L2) تلامس منحنيات الخسارة في نقطة عامّة فتبقى كلّ المعاملات غير صفرية؛ والمعيّن (L1) يلامس من زاوية فيصفُر أحد المعاملات. </figcaption>

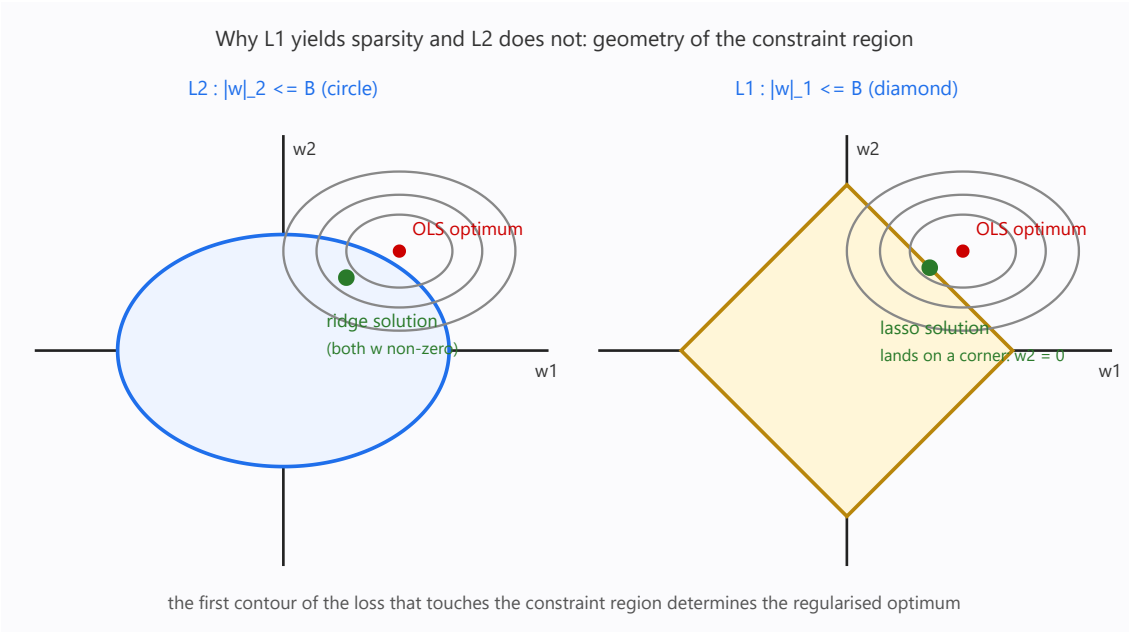
البرهان

الخطوة 1 (صيغة الحيد): باشتقاق $\frac{1}{n}\|y - Xw\|^2 + \lambda\|w\|^2$: $-\frac{2}{n}X^\top(y - Xw) + 2\lambda w = 0 \Rightarrow (X^\top X + n\lambda I)w = X^\top y$ $\Rightarrow$ (12.30) بعد إعادة تعريف λ.

الخطوة 2 (الشرط الحديّ): $X^\top X + n\lambda I \succ X^\top X$ $\Rightarrow$ الحيد يحسّن شرط المصفوفة $\Rightarrow$ استقرار عددي (قارن الفصل 6).

الخطوة 3 (عامل الانكماش): بتصميم متعامد $X^\top X = \operatorname{diag}(s)$: $\hat{w}_j = \frac{s_j}{s_j + n\lambda}\hat{w}_j^{\text{OLS}}$ $\Rightarrow$ انكماش بعامل < 1 يصغر مع λ.

الخطوة 4 (لماذا L1 يُصفّر): شرط KKT عند $w_j = 0$ (من الفصل 21) هو $|g_j| \leq \lambda$ حيث g_j تدرّج الخسارة؛ أي أنّ منطقة «البقاء صفراً» ذات عرض 2λ — بخلاف L2 التي لا تملك نقطة غير قابلة للاشتقاق. هندسياً: زوايا المعيّن هي نقاط التماس الأولى. ■



شكل ٣٠.٥: *
هندسة L1 مقابل L2

الخطوة 5 (التحيز–التباين): من (12.30) في الأساس المتعامد: $\hat{w}_\lambda = \frac{s}{s+n\lambda}(\theta + \text{ضجيج})$ ⇒ التباين والانحياز بصيغة (14.30). ■

خمسة عشر مثالاً محلولاً

مثال (1-5.30): حلّ الحيد المغلق المعطيات: $X^\top X = \text{diag}(2,1)$، $X^\top y = (4,3)$، $\lambda = 1$ (بالصيغة $(X^\top X + \lambda I)$). المطلوب: $\hat{w}$. الحل: الخطوة 1: OLS: $(2,3)$ $= (4/2,\ 3/1)$ $= w$. الخطوة 2: الحيد: $(4/3,\ 3/2) = (1.333,\ 1.5)$. النتيجة: انكماش بنسبة $2/3$ و $1/2$ — الأضعف دلالةً ينكمش أكثر. الربط بالذكاء الاصطناعي: التنظيم يعاقب الاتجاهات قليلة المعلومات أكثر (قارن متر فيشر، الفصل 29).

مثال (2-5.30): أثر تشديد λ المعطيات: نفس المسألة بـ $\lambda = 10$. المطلوب: $\hat{w}$. الحل: الخطوة 1: $(4/12,\ 3/11) = (0.333,\ 0.273) = w$. النتيجة: انكماش شديد ⇒ تحيز كبير (خطر التفريط). الربط بالذكاء الاصطناعي: علامة التشخيص: خطأ التدريب وخطأ التحقّق يرتفعان معاً.

مثال (3-5.30): عتبة التناثر في L1 المعطيات: تصميم متعامد، معاملات OLS $z = (3,\ -1.2,\ 0.5)$، $\lambda' = 1$. المطلوب: حلّ اللاسو. الحل: الخطوة 1: $|3| - 1 = 2 \Rightarrow \hat{w}_1 = 2$. الخطوة 2: $|-1.2| - 1 = 0.2 \Rightarrow \hat{w}_2 = -0.2$. الخطوة 3: $|0.5| - 1 < 0 \Rightarrow \hat{w}_3 = 0$. النتيجة: اللاسو انتقى متغيّرين وأسقط الثالث. الربط بالذكاء الاصطناعي: انتقاء الخصائص مدمجاً في التدريب — ذهب في النماذج القابلة للتفسير.

مثال (4-5.30): لماذا الزوايا تُصفّر؟ المعطيات: خسارة محدّبة ومنطقة قيد L1. المطلوب: التفسير الهندسي. الحل: الخطوة 1: الحلّ = أوّل منحنى خسارة يلامس المنطقة. الخطوة 2: للمعيّن، نقاط التماس الأولى غالباً زوايا (على المحاور) ⇒ معامل واحد يصفُر. النتيجة: التناثر نتيجة هندسية لا نتيجة «رغبة في البساطة». الربط بالذكاء الاصطناعي: كلّ عقوبات التناثر (group lasso، nuclear norm) تعمل بالآليّة نفسها.

مثال (5-5.30): تكافؤ الصيغة المقيّدة والمجزَّأة المعطيات: $\min \hat{R}$ s.t. $\|w\|_2^2 \le B$. المطلوب: العلاقة بـ (11.30). الحل: الخطوة 1: لاغرانج: $\hat{R} + \lambda(\|w\|^2 - B)$ ⇒ نفس صيغة (11.30) بثابت. الخطوة 2: بشرط المحدّبية (Slater) لا فجوة ازدواج ⇒ لكلّ B يوجد λ والعكس. النتيجة: الصيغتان وجهان لعملة واحدة. الربط بالذكاء

الاصطناعي: عملياً نضبط λ (أسهل عددياً) ونقرأ النتيجة بوصفها سعةً مقيَّدة.

مثال (30.5-6): اضمحلال الوزن ليس دائماً L2 المعطيات: شبكة بمُحسِّن Adam و decay. weight. المطلوب: هل يعادل تنظيم L2؟ الحل: الخطوة 1: L2 يضيف $\lambda\|w\|^2$ للخسارة $\Rightarrow$ تدرّجه $2\lambda w$. الخطوة 2: مع Adam يُقسَم التدرّج على $\sqrt{\mathbb{E}[g^2]}$ $\Rightarrow$ أثر الاضمحلال يتغيّر بتكيّف المُحسِّن. النتيجة: decay weight مع Adam $\neq$ L2 (يُنصح بـ AdamW). الربط بالذكاء الاصطناعي: تفصيلٌ عمليّ مهمّ في تدريب المحوّلات (الفصل decoupled weight، decay، 39).

مثال (30.5-7): مسار التنظيم المعطيات: نريد مسح λ من 10^{-4} إلى 10^{2}. المطلوب: شبكة القيم. الحل: الخطوة 1: شبكة لوغاريتمية: 20 قيمة بمسافات متساوية في $\log_{10}$. الخطوة 2: رسم خطأ التحقّق مقابل $\log\lambda$ (منحنى U). النتيجة: الذروة تعطي $\lambda^\star$. الربط بالذكاء الاصطناعي: إجراء قياسي في كلّ مكتبات التعلّم (scikit-learn وغيرها).

مثال (30.5-8): اختيار λ بالتحقق المتقاطع وقاعدة SE المعطيات: 5 أضعاف، أفضل λ بخطأ 0.21، خطأ نموذج أبسط بـ λ أكبر 0.215 =، والانحراف المعياري للأضعاف 0.01 =. المطلوب: أيّ نموذج نختار؟ الحل: الخطوة 1: قاعدة «1-SE»: اختر أبسط نموذج داخل خطأ معياري واحد من الأفضل. الخطوة 2: الحدّ $0.21 + 0.01 = 0.22$ $\Rightarrow$ 0.215 داخل الحدّ $\Rightarrow$ نختار الأبسط. النتيجة: تفضيل البساطة عند التعادل الإحصائي. الربط بالذكاء الاصطناعي: قاعدة مستقرّة في الممارسة الإحصائية.

مثال (30.5-9): الشبكة المرنة (elastic net) المعطيات: عقوبة $\alpha\|w\|_1 + (1-\alpha)\|w\|_2^2$ بـ $\alpha = 0.5$. المطلوب: متى نستخدمها؟ الحل: الخطوة 1: L1 يختار متغيّراً واحداً من مجموعة مترابطة بقوّة. الخطوة 2: L2 يوزّع الأوزان بين المترابطة $\Rightarrow$ أكثر استقراراً. النتيجة: المزيج يجمع التناثر والاستقرار (مهمّ في الجينوم والتصوير الطبي). الربط بالذكاء الاصطناعي: مفيد عند $d \gg n$ مع ارتباطات قويّة بين الخصائص.

مثال (30.5-10): التنظيم بوصفه سابقة بايزية المعطيات: MAP من الفصل 18. المطلوب: مقابل L2 و L1. الحل: الخطوة 1: سابقة غاوسية $\Rightarrow$ عقوبة $\|w\|_2^2$. الخطوة 2: سابقة لابلاس $\Rightarrow$ عقوبة $\|w\|_1$. النتيجة: التنظيم = إدخال معرفة سابقة؛ وλ يرتبط بتباين السابقة. الربط بالذكاء الاصطناعي: يوحّد التنظيم والاستدلال البايزي في صورة واحدة.

مثال (30.5-11): التنظيم يحسّن الشرط العددي المعطيات: قيم $X^\top X$ الذاتية: 10^{-6} و 1 $\Rightarrow$ رقم الشرط 10^6؛ $\lambda = 0.01$. المطلوب: الشرط بعد التنظيم. الحل: الخطوة 1: القيم تصير 0.010001 و 1.01. الخطوة 2: الشرط $101 \approx$. النتيجة: تحسّن بأربعة مراتب $\Rightarrow$ حساب مستقرّ وتقارب أسرع. الربط بالذكاء الاصطناعي: يربط هذا الفصل بالفصل السادس (الاستقرار العددي).

مثال (30.5-12): التنظيم يقلّل تباين المقدّر المعطيات: $s = 1$، $\sigma^2 = 1$؛ λ من 0 إلى 2. المطلوب: أثره على التباين. الحل: الخطوة 1: $\lambda = 0$: Var $= 1$. الخطوة 2: $\lambda = 2$: Var $= 1/9 = 0.111$. النتيجة: تقليل التباين بتسعة أضعاف مقابل تحيز يكبر. الربط بالذكاء الاصطناعي: الصيغة الكمّية وراء قولنا «التنظيم يضادّ الإفراط في الملاءمة».

مثال (30.5-13): تكثير البيانات تنظيمٌ معلوماتي المعطيات: تدوير وقصّ عشوائي للصور. المطلوب: أثره على السعة. الحل: الخطوة 1: التكثير يفرض «ثباتاً» على الفرضيات المسموحة $\Rightarrow$ يصغّر $\mathcal{H}$ الفعّالة. الخطوة 2: لا يغيّر عدد المعلمات لكنّه يقيّد الاتجاهات المفيدة. النتيجة: تنظيمٌ عبر فرض تماثلات (قارن الفصل 37 عن الالتفاف). الربط بالذكاء الاصطناعي: أقوى أشكال التنظيم في الرؤية الحاسوبية.

مثال (30.5-14): التوقّف المبكر تنظيمٌ ضمني المعطيات: هبوط تدرّجي بمعدّل η بعد t خطوة على مسألة خطّية. المطلوب: ما يعادله من λ. الحل: الخطوة 1: في انحدار الحيد، التوقّف عند t يعادل تنظيماً بـ $\lambda \approx \frac{1}{\eta t}$. الخطوة 2: كلّما طال التدريب ضعف التنظيم. النتيجة: التوقّف المبكر = تنظيم مجّاني (بلا تكلفة حسابية إضافية). الربط بالذكاء الاصطناعي: يفسّر لماذا «تدريب أطول» قد يضرّ أحياناً.

مثال (15-5.30): الانحياز الضمني للمُحسِّن في النماذج مفرطة المعلمات المعطيات: شبكة بأصفار خطأ تدريبي (عديد من الحلول الممكنة). المطلوب: أيّ حلّ يجدها هبوط التدرّج؟ الحل: الخطوة 1: من بين كلّ الحلول المطابقة للبيانات، يميل GD إلى **أصغر معيار**. الخطوة 2: أصغر معيار = تنظيم ضمني بلا عقوبة صريحة. النتيجة: «التنظيم الضمني» يفسّر تعميم الشبكات الضخمة بلا تنظيم صريح. الربط بالذكاء الاصطناعي: هذه البوابة إلى الفصل 34 (حدود التعميم في الشبكات العميقة).

أخطاء شائعة

- ضبط λ على بيانات الاختبار (تسرّب).
- تطبيق L2 على معلمات التحيز أو على طبقات التطبيع بلا تفكير.
- الظنّ أنّ التنظيم يقلّل خطأ التدريب (هو يرفعه ويقلّل خطأ التعميم).
- الخلط بين decay weight و L2 مع المُحسِّنات التكيفية.
- تنظيم «كلّ شيء» بدل تصميم عقوبة تعبّر عن المعرفة السابقة الحقيقية.

المبرهنة: ليكن h قد تقرّر (أو صار اختياره) **قبل** رؤية مجموعة التحقّق V بحجم m، والخسارة محصورة في $[0,1]$. فباحتمال $\geq 1-\delta$:

$$\left|R(h) - \hat{R}_V(h)\right| \;\leq\; \sqrt{\frac{\ln(2/\delta)}{2m}} \tag{15.30}$$

وإذا استُخدمت V لاختيار أفضل نموذج من بين K مرشّحين (تصحيح اتّحاد):

$$\forall h \in \{h_1,\dots,h_K\}: \quad \left|R(h) - \hat{R}_V(h)\right| \;\leq\; \sqrt{\frac{\ln(2K/\delta)}{2m}} \tag{16.30}$$

أمّا التحقق المتقاطع بـ k أضعاف فيُعرَّف بمقدّر

$$\widehat{R}_{\mathrm{CV}} \;=\; \frac{1}{k}\sum_{j=1}^{k} \hat{R}_{S_j}\big(A(S_{-j})\big), \qquad S=\bigsqcup_{j=1}^{k} S_j \tag{17.30}$$

وهو **غير متحيّز لخطر نموذج مدّرب على** $n(1-\frac{1}{k})$ **عيّنة** (متشائم قليلاً لنموذج مدّرب على n)، ويرث تفاؤل اختيار النموذج:

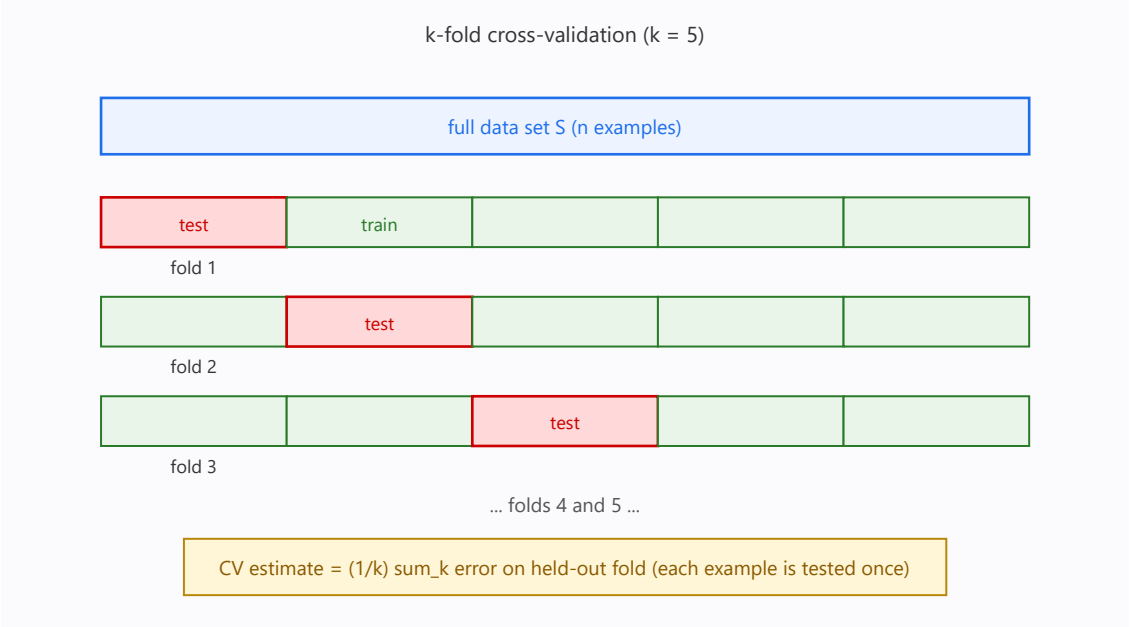
$$R(\hat{h}) - \hat{R}_S(\hat{h}) \;\leq\; \sup_{h\in\mathcal{H}} \left|R(h) - \hat{R}_S(h)\right| \tag{18.30}$$

جدول الرموز

الرمز	المعنى	ملاحظة
V	مجموعة التحقّق	حجمها m
K	عدد المرشّحين المُختبرين	يرفع الحدّ بـ $\ln K$
S_{-j}	كلّ البيانات عدا الضعف j	حجمها $n(1-1/k)$
S_j	الضعف المحتجَز	يُستخدم للتقييم مرّة واحدة
LOO	$k=n$	تحيز شبه معدوم وتباين عالٍ
تصحيح الاتّحاد	$\delta \mapsto \delta/K$	ثمن الاختيار على نفس البيانات

الرسم

<figure> الشكل<figcaption> ٦.٣٠: في التحقق المتقاطع ذي الخمسة أضعاف يُدرَّب النموذج خمس مرّات على 80%



شكل ٦.٣٠: *
التحقق المتقاطع ذو الخمسة أضعاف

من البيانات ويُقيَّم على الـ20% المحتجزة، ثمّ يُتوسَّط الخطأ.</figcaption> </figure>

البرهان

الخطوة 1: بعد تثبيت h (أو تثبيت آليّة الاختيار بصيغة الحدّ على «كلّ المرشّحين معاً»)، تكون خسائر عيّنات التحقّق $\ell(h(x_i),y_i)$ متغيّرات i.i.d. في $[0,1]$ بمتوسط $R(h)$ $\Rightarrow$ هوفدينغ يعطي (15.30).

الخطوة 2 (الاختيار): بتطبيق (15.30) على كلّ مرشّح بـ δ/K ثمّ اتّحاد الاحتمالات: $\delta = K \cdot \frac{\delta}{K}$ $\Rightarrow$ (16.30). ■

الخطوة 3 (لماذا CV متشائم): كلّ نموذج في (17.30) دُرّب على $n - n/k$ عيّنة فقط، ومنحنى التعلّم هابط في n $\Rightarrow$ $\widehat{R}_{\mathrm{CV}}$ يقدّر خطر نموذج أصغر حجماً بقليل $\Rightarrow$ يميل إلى **المبالغة** في تقدير الخطأ. ■

الخطوة 4 (التفاؤل): من تعريف $\hat{h}$ كمقلّل للخطر التجريبي: $\hat{R}(\hat{h}) \le \hat{R}(h^\star_{\mathcal{H}})$، أمّا $R(\hat{h})$ فقد يتجاوز $R(h^\star_{\mathcal{H}})$ بمقدار لا يزيد على $\sup|\cdot|$ $\Rightarrow$ (18.30). ■

خمسة عشر مثالاً محلولاً

مثال (30.6-1): تقسيم البيانات المعطيات: 10,000 عيّنة. المطلوب: تقسيم تدريب/تحقّق/اختبار. الحل: الخطوة 1: تدريب 70%، تحقّق 15%، اختبار 15% $\Rightarrow$ 7000/1500/1500. الخطوة 2: الاختبار يُلمس مرّة واحدة في النهاية. النتيجة: طبقات ثلاث تحمي من تسرّب الاختيار. الربط بالذكاء الاصطناعي: البنية القياسية لأيّ مشروع تعلّم آلة جادّ.

مثال (30.6-2): دقّة تقدير التحقّق المعطيات: $m = 3000$، $\delta = 0.05$. المطلوب: هامش تقدير الخطر. الحل: الخطوة 1: $\sqrt{\ln(2/0.05)/(2 \times 3000)} = \sqrt{3.689/6000} = 0.0248$. النتيجة: $\varepsilon \approx \pm 2.5$ نقطة مئوية. الربط بالذكاء الاصطناعي: فروقٌ أصغر من ذلك بين نموذجين ليست دليلاً.

مثال (30.6-3): ثمن اختيار الأفضل من 100 المعطيات: $K = 100$ مرشّحاً على نفس التحقّق، $m = 3000$، $\delta = 0.05$. المطلوب: الهامش بعد التصحيح. الحل: الخطوة 1: $\ln(2 \times 100/0.05) = \ln(4000) = 8.294$. الخطوة 2: $\varepsilon = \sqrt{8.294/6000} = 0.0372$. النتيجة: اتّسع الهامش من 5.2% إلى 7.3%. الربط بالذكاء الاصطناعي: كلّما كثر ما تجرّبه على التحقّق، قلّت موثوقيّة أفضل نتيجة.

مثال (30.6-4): لعنة الفائز (winner's curse) المعطيات: 100 نموذج خطرها الحقيقي 0.20 جميعاً؛ نقيس على $m = 1000$. المطلوب: القيمة المتوقّعة لأفضل نتيجة مقاسة. الحل: الخطوة 1: الانحراف المعياري للخطأ المقاس $= \sqrt{0.2 \times 0.8/1000} = 0.0126$. الخطوة 2: توقّع أصغر 100 قراءة $\approx$ المتوسط -2.5 انحرافاً معيارياً $\approx 0.20 - 0.0316 = 0.168$. النتيجة: أفضل نموذج مقاساً يبدو أفضل من الحقيقة بنحو 3 نقاط. الربط بالذكاء الاصطناعي: لهذا يُبلَّغ الأداء على مجموعة اختبار لم تُستخدم في الاختيار.

مثال (30.6-5): اختيار k في التحقق المتقاطع المعطيات: $n = 1000$. المطلوب: مقارنة $k = 5$ و $k = 10$ و LOO. الحل: الخطوة 1: $k = 5$: تدريب على 800، تكلفة 5 تدريبات، تحيز متوسط. الخطوة 2: $k = 10$: تدريب على 900، تكلفة 10 تدريبات، تحيز أقلّ. الخطوة 3: LOO: تدريب على 999، تكلفة 1000 تدريب، تباين عالٍ. النتيجة: $k = 5$ أو 10 هو التوازن المعتاد. الربط بالذكاء الاصطناعي: مع الشبكات العميقة قد نكتفي بضعف واحد بسبب التكلفة.

مثال (30.6-6): لماذا CV متشائم؟ المعطيات: $n = 100$، $k = 5$ $\Rightarrow$ تدريب على 80. المطلوب: ماذا يقدّر $\widehat{R}_{CV}$؟ الحل: الخطوة 1: يقدّر خطر نموذج مدّرب على 80 عيّنة. الخطوة 2: منحنى التعلّم هابط $\Rightarrow$ خطر الـ80 أكبر من خطر الـ100. النتيجة: CV يميل للمبالغة في الخطأ (تحيز متشائم)، بعكس خطأ التدريب (متشائم؟ لا: متفائل). الربط بالذكاء الاصطناعي: فهم اتّجاه التحيز يساعد في تفسير الفجوة عن خطأ الاختبار.

مثال (30.6-7): تباين LOO المعطيات: LOO على $n = 200$ مع نموذج حسّاس للنقاط الشاذّة. المطلوب: الخطر الرئيسي. الحل: الخطوة 1: كلّ نموذج يُدرَّب على بيانات تختلف بنقطة واحدة $\Rightarrow$ المقدّرات مترابطة بقوّة. الخطوة 2: ترابط عالٍ $\Rightarrow$ تباين مرتفع لمقدّر CV رغم التحيز شبه المعدوم. النتيجة: LOO ليس «الأفضل دائماً»؛ $k = 10$ أفضل غالباً. الربط بالذكاء الاصطناعي: درس عامّ: مقايضة تحيز–تباين تطال **مقدّر الأداء** نفسه.

مثال (30.6-8): التحقق الطبقي (stratfiied) المعطيات: 1% أمثلة موجبة. المطلوب: كيف نبني الأضعاف؟ الحل: الخطوة 1: عيّنة عشوائية بسيطة قد تضع كلّ الموجبات في ضعف واحد. الخطوة 2: الطبقية تحفظ النسبة (1%) في كلّ ضعف. النتيجة: تقدير مستقرّ للفئة النادرة. الربط بالذكاء الاصطناعي: إجراء إلزامي في التطبيقات الطبية والأمنية.

مثال (30.6-9): السلاسل الزمنية — لا خلط المعطيات: بيانات أسعار يومية. المطلوب: تصميم التحقق. الحل: الخطوة 1: الخلط العشوائي يضع المستقبل في التدريب والماضي في الاختبار $\Rightarrow$ تسرّب زمني. الخطوة 2: نستخدم تحقّقاً «متقدّماً» (forward chaining): درّب على $[1, t]$ واختبر على $[t+1, t+h]$. النتيجة: أداء واقعي أصغر بكثير من

أداء الخلط، لكنّه الصادق. الربط بالذكاء الاصطناعي: خطأ شائع جدّاً في النماذج المالية (قارن الفصل 19).

مثال (30.6-10): التحقق المتداخل nested) (CV المعطيات: نريد تقدير أداء «إجراء اختيار النموذج» كاملاً. المطلوب: التصميم. الحل: الخطوة 1: حلقة داخلية تختار المعاملات الفائقة؛ حلقة خارجية تُقيّم. الخطوة 2: تكلفة (عدد الشبكات) $\times$ k_{in} $\times$ k_{out} = تدريب. النتيجة: التقدير الوحيد غير المتفائل لأداء المنهجيّة كلها. الربط بالذكاء الاصطناعي: معيار الأبحاث التي تقارن «طريقة اختيار» لا «نموذجاً».

مثال (30.6-11): لمسة الاختبار المعطيات: رأيت نتيجة الاختبار فعدّلت النموذج، ثمّ أعدت القياس ثلاث مرّات. المطلوب: التقييم. الحل: الخطوة 1: الاختبار صار جزءاً من عمليّة الاختيار $\Rightarrow$ ينطبق (30.16) مع K = عدد المحاولات. الخطوة 2: النتيجة المبلَّغة متفائلة. النتيجة: «مجموعة الاختبار تُلمس مرّة واحدة» قاعدة أخلاقية وإحصائية معاً. الربط بالذكاء الاصطناعي: يفسّر ظاهرة تضخّم النتائج عند إعادة استخدام معايير التقييم.

مثال (30.6-12): تسرّب البيانات في التطبيع المعطيات: طبّقت تطبيعاً (StandardScaler) على كلّ البيانات قبل التقسيم. المطلوب: الخطأ. الحل: الخطوة 1: المتوسط والانحراف المحسوبان يتضمّنان عيّنات الاختبار. الخطوة 2: الجزء الأكبر من «الأداء» جاء من معلومات مسروقة. النتيجة: يجب أن يُدرَّب كلّ محوّل على التدريب فقط ثمّ يُطبَّق على التحقّق والاختبار. الربط بالذكاء الاصطناعي: أكثر أخطاء التسرّب شيوعاً في الممارسة.

مثال (30.6-13): مقارنة نموذجين على نفس الاختبار المعطيات: نموذجان بدقّة 91% و92% على 1000 عيّنة، وأخطاؤهما متداخلة كثيراً. المطلوب: هل الفرق حقيقي؟ الحل: الخطوة 1: المقارنة المستقلّة تعطي SE للفرق $\sqrt{2p(1-p)/m} = \sqrt{2(0.09)/1000} = 0.0134$. الخطوة 2: الفرق $0.026 = 1.96 \times 0.0134$ $\approx$ $0.01 <$ $\Rightarrow$ غير دالّ. النتيجة: الأصحّ استخدام اختبار مزدوج (مثل مكنيمار) لأنّ الأخطاء مترابطة. الربط بالذكاء الاصطناعي: فروق النقطة المئوية الواحدة نادراً ما تكون حقيقية عند $m = 1000$.

مثال (30.6-14): حجم الاختبار لكشف تحسّن 1% المعطيات: $p = 0.90$؛ نريد كشف فرق 0.01 بثقة 95%. المطلوب: m. الحل: الخطوة 1: $1.96\sqrt{2(0.09)/m} \leq 0.01 \Rightarrow 0.005102 \leq \sqrt{0.18/m}$. الخطوة 2: $m \geq 6915 \Rightarrow 0.18/m \leq 2.603 \times 10^{-5}$. النتيجة: نحو 7000 عيّنة اختبار مستقلّة. الربط بالذكاء الاصطناعي: تصميم معايير التقييم يحتاج حساباً مسبقاً لا اجتهاداً.

مثال (30.6-15): الخطأ المعياري لمقدّر CV المعطيات: 5 أضعاف أعطت أخطاء $0.20, 0.24, 0.18, 0.26, 0.22$. المطلوب: تقدير وعدم يقين. الحل: الخطوة 1: المتوسط $= 0.22$. الخطوة 2: الانحراف المعياري $0.032 =$ $\Rightarrow$ SE للمتوسط $0.032/\sqrt{5} = 0.0143$. الخطوة 3: فترة تقريبية $[0.19,\ 0.25]$ (باحتراس: الأضعاف مترابطة). النتيجة: أبلغ المتوسط وعدم اليقين دائماً. الربط بالذكاء الاصطناعي: التكرار المتعدد للتحقق المتقاطع يقلّل هذا التباين.

أخطاء شائعة

- اختيار المعاملات الفائقة على مجموعة الاختبار.
- تطبيق التطبيع/اختيار الخصائص قبل التقسيم.
- خلط البيانات الزمنية عشوائيّاً.
- مقارنة نماذج بفروق داخل هامش الخطأ الإحصائي.
- الظنّ أنّ CV يعطي «الحقيقة» بدل «تقديراً متحيّزاً قليلاً وله تباين».

المبرهنة (الاتساق والتقارب الموحّد): خوارزمية A **متّسقة** لفضاء $\mathcal{H}$ إذا

$$\mathbb{E}_S\big[R(A(S))\big] \xrightarrow[n\to\infty]{} \inf_{h\in\mathcal{H}} R(h) \qquad \text{لكلّ توزيع } \mathcal{D} \tag{19.30}$$

وخوارزمية ERM على $\mathcal{H}$ متّسقة **إذا وفقط إذا** حقّق $\mathcal{H}$ التقارب الموحّد: $\sup_{h\in\mathcal{H}} |\hat{R}_S(h) - R(h)| \xrightarrow{P} 0$.

مبرهنة «لا غداء مجاني» (Wolpert–Macready) / فابنيك:

ليكن $\mathcal{X}$ منتهياً بحجم N و $\mathcal{F}$ مجموعةَ **كلّ** الدوالّ $\mathcal{X} \to \{0,1\}$ ($|\mathcal{F}| = 2^N$) موزّعةً توزيعاً منتظماً. فلكلّ خوارزميتَي تعلّم A و B:

$$\frac{1}{|\mathcal{F}|}\sum_{f\in\mathcal{F}} R_f\big(A(S_f)\big) \;=\; \frac{1}{|\mathcal{F}|}\sum_{f\in\mathcal{F}} R_f\big(B(S_f)\big) \;=\; \frac{1}{2}\cdot\frac{N-n}{N} \tag{20.30}$$

أي أنّ الأداء **المتوسط على كلّ المسائل الممكنة** متطابق لكلّ الخوارزميات؛ التفوّق ممكن فقط على توزيعات ذات بنية.

جدول الرموز

الرمز	المعنى	ملاحظة
اتّساق	تقارب الخطر إلى أفضل ما في $\mathcal{H}$	خاصية مقارِبة ($n\to\infty$)
تقارب موحّد	$\sup_{\mathcal{H}} \lvert\cdot\rvert \to 0$	شرط كافٍ وضروري لـ ERM
$\mathcal{F}$	كلّ دوالّ الوسم الممكنة	حجمها 2^N
$N-n$	النقاط غير المشاهدة	نصفها يُخطأ بالمتوسط
انحياز استقرائي	افتراض مسبق عن $\mathcal{D}$	الثمن الضروري للتفوّق

البرهان (مخطّط)

الخطوة 1 (اتّساق ERM $\Rightarrow$ تقارب موحّد): لو لم يكن التقارب الموحّد، لوجدنا توزيعاً تتّبع فيه أفضل فرضية تجريبياً أسوأ كثيراً من أفضل فرضية حقيقة $\Rightarrow$ لا يتقارب الخطر $\Rightarrow$ تناقض. والعكس يتبع مباشرة: $R(\hat{h}) \le \hat{R}(\hat{h}) + \sup|\cdot| \le \hat{R}(h^\star) + \sup|\cdot| \to R(h^\star)$.

الخطوة 2 (NFL): بالتناظر: لكلّ دالّة f تقابلها دالّة معكوسة الوسم؛ وبتوزيع منتظم على $\mathcal{F}$، فإنّ سلوك أيّ خوارزمية على النقاط غير المشاهدة متماثل $\Rightarrow$ متوسط الخطأ على النقاط غير المشاهدة $= \frac{1}{2}$، وعلى نقاط التدريب $= 0$ $\Rightarrow$ (20.30). ■

الخطوة 3 (القراءة): الفرض الجوهري هو «كلّ التوزيعات متساوية الاحتمال»؛ وحين نقيّد إلى عائلة ذات بنية (سلاسة، تماثل، تناثر) يصير التفوّق ممكناً. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.30): اتّساق فضاء منته المعطيات: $|\mathcal{H}| = 1000$ ثابت، نزيد n بلا حدود. المطلوب: هل ERM متّسقة؟ الحل: الخطوة 1: هامش التقارب الموحّد $\sqrt{\ln(2000/\delta)/(2n)} \to 0$. الخطوة 2: إذن $R(\hat{h}) \to \inf_{\mathcal{H}} R$. النتيجة: فضاء السعة الثابتة $\Rightarrow$ اتّساق تلقائي. الربط بالذكاء الاصطناعي: ضمان نظري لكلّ نموذج ذي سعة محدودة.

مثال (2-7.30): الحافظ (memorizer) غير متّسق المعطيات: $\mathcal{H}$ = كلّ الدوالّ؛ الخوارزمية تحفظ التدريب وتخمّن عشوائيّاً خارجها. المطلوب: الاتّساق. الحل: الخطوة 1: $\hat{R}_S = 0$ دائماً، لكن $R \approx \frac{1}{2}$ دائماً. الخطوة 2: لا تقارب

$\Rightarrow$ غير متّسقة. النتيجة: التقارب الموحّد مفقود $\Rightarrow$ لا ضمان. الربط بالذكاء الاصطناعي: الشبكة الضخمة بلا تنظيم ولا انحياز ضمني تقترب من هذا السيناريو.

مثال (30.7-3): شروط اتساق أقرب الجيران المعطيات: خوارزمية k-NN. المطلوب: شروط $k(n)$ للاتساق. الحل: الخطوة 1: نحتاج $k \to \infty$ (لكبح التباين) و $k/n \to 0$ (لكبح التحيز). الخطوة 2: مثال عملي: $k = \sqrt{n}$ $\Rightarrow$ عند $n = 1000$ نأخذ $k \approx 32$. النتيجة: k يجب أن ينمو مع البيانات لا أن يثبت. الربط بالذكاء الاصطناعي: يفسّر الحاجة لإعادة ضبط المعاملات الفائقة عند تغيّر حجم البيانات.

مثال (30.7-4): تنظيم متضائل المعطيات: انحدار نواة بعقوبة λ_n. المطلوب: شرط الاتساق. الحل: الخطوة 1: نحتاج $\lambda_n \to 0$ (لكبح التحيز) و $n\lambda_n \to \infty$ (لكبح التباين). الخطوة 2: مثال: $\lambda_n = n^{-1/2}$ $\Rightarrow$ عند $n = 10^4$ نأخذ $\lambda = 0.01$. النتيجة: التنظيم يجب أن يضعف مع نموّ البيانات. الربط بالذكاء الاصطناعي: قاعدة عملية: أعد ضبط λ عند كلّ زيادة كبيرة في البيانات.

مثال (30.7-5): أرقام «لا غداء مجاني» المعطيات: مُدخلات ثنائية بـ $d = 20 \Rightarrow N = 2^{20} \approx 1.05 \times 10^6$ نقطة ممكنة؛ عيّنة $n = 1000$. المطلوب: متوسط الخطأ لأيّ خوارزمية. الحل: الخطوة 1: نسبة النقاط غير المشاهدة $(N-n)/N \approx 0.999 =$. الخطوة 2: متوسط الخطأ $\frac{1}{2} \times 0.999 \approx 0.4995 =$. النتيجة: على «كلّ المسائل الممكنة» لا يتفوّق شيء على التخمين العشوائي تقريباً. الربط بالذكاء الاصطناعي: المسائل الواقعية ليست عشوائية — ولذلك تنجح الخوارزميات.

مثال (30.7-6): حجم فضاء المسائل المعطيات: $N = 2^{20}$ نقطة. المطلوب: عدد دوالّ الوسم الممكنة. الحل: الخطوة 1: $|\mathcal{F}| = 2^N = 2^{1{,}048{,}576}$ — عدد يفوق عدد ذرّات الكون المرصود بمراتب. النتيجة: المتوسط على هذا الفضاء ليس له معنى عملي مباشر. الربط بالذكاء الاصطناعي: قيمة النظرية تحذيرية ومنهجية لا كمّية.

مثال (30.7-7): NFL لا تعني «الخوارزميات متساوية في الواقع» المعطيات: مسألتان: الأولى صور طبية، والثانية وسوم عشوائية. المطلوب: تفسير نجاحنا في الأولى وفشلنا في الثانية. الحل: الخطوة 1: NFL تفترض توزيعاً منتظماً على **كلّ** المسائل. الخطوة 2: المسائل الواقعية مركّزة على عائلة ضئيلة جدّاً (سلاسة، تماثل، سببية). النتيجة: التفوّق ممكن بدقة **بقدر ما** تتطابق انحيازات النموذج مع بنية العالم. الربط بالذكاء الاصطناعي: هذا هو التعريف الرسمي لـ«الانحياز الاستقرائي» (inductive bias).

مثال (30.7-8): NFL والتعلّم الآلي التلقائي (AutoML) المعطيات: بحث تلقائي في فضاء معماري واسع. المطلوب: ما الذي تُنذر به NFL؟ الحل: الخطوة 1: لا توجد «أفضل معمارية لكلّ المسائل». الخطوة 2: البحث التلقائي يفيد **داخل** عائلة مسائل متشابهة فقط. النتيجة: قيمة AutoML مستمدّة من البنية المشتركة لا من عمومية البحث. الربط بالذكاء الاصطناعي: يبرّر «نقل» المعاملات الفائقة بين مسائل متشابهة.

مثال (30.7-9): لا غداء مجاني في التحسين المعطيات: مقارنة مُحسِّنَين على كلّ الدوالّ الممكنة. المطلوب: النتيجة. الحل: الخطوة 1: مبرهنة وولبرت–ماكريدي: متوسط أداء كلّ مُحسِّنين متطابق على كلّ الدوالّ. الخطوة 2: التفوّق مرهون ببنية الدالّة (محدّبية، سلاسة، شرط). النتيجة: مرآة NFL في فضاء التحسين (قارن الفصل 25). الربط بالذكاء الاصطناعي: يبرّر اختيار المُحسِّن حسب نوع المسألة لا ادّعاء العمومية.

مثال (30.7-10): الاتساق الشامل (universal consistency) المعطيات: خوارزمية k-NN بالشروط أعلاه. المطلوب: إلى أيّ حدٍّ تتقارب؟ الحل: الخطوة 1: تتقارب إلى $R^\star$ (خطر بايز) **لأيّ** توزيع — بلا افتراض نموذجي. النتيجة: الاتساق الشامل ميزة نادرة وثمينة. الربط بالذكاء الاصطناعي: يقابلها في التعلّم العميق «نظريات التقريب الشامل» (الفصل 35).

مثال (30.7-11): المعدّلات لا الاتساق فقط المعطيات: نموذج معلمي (d ثابت) مقابل غير معلمي في بُعد $d = 10$. المطلوب: مقارنة المعدّل. الحل: الخطوة 1: المعلمي: خطأ التقدير $\approx n^{-1/2}$. الخطوة 2: غير المعلمي:

$n^{-1/6} = n^{-2/(2+d)} \approx$ عند $d = 10$. الخطوة 3: لتقليل الخطأ إلى النصف: المعلمي يحتاج $4\times$ البيانات، وغير المعلمي $64\times = 2^6$. النتيجة: «لعنة الأبعاد» تحدّد **معدّل** التعلّم لا صحّته. الربط بالذكاء الاصطناعي: يبرّر التعلّم بالتمثيل (representation learning): خفّض d الفعّال أوّلاً.

مثال (30.7-12): الإفراط $\neq$ عدم الاتساق المعطيات: نموذج خطّي على علاقة تربيعية. المطلوب: هل يفرط في الملاءمة؟ الحل: الخطوة 1: لا — هو «يفرّط في التبسيط» (underfitting). الخطوة 2: غير متّسق **لأفضل فرضية في** $\mathcal{H}$ لكنّه مستقرّ. النتيجة: عدم الاتساق قد يأتي من قصور $\mathcal{H}$ لا من حفظ الضجيج. الربط بالذكاء الاصطناعي: خطأ التشخيص الشائع: «خطأ تدريب مرتفع» $\Rightarrow$ ليست مشكلة تنظيم.

مثال (30.7-13): الاتساق لا يكفي المعطيات: خوارزميتان متّسقتان. المطلوب: أيّهما أفضل؟ الحل: الخطوة 1: الاتساق خاصية limit ($n \to \infty$) لا تخبر عن سلوك $n = 500$. الخطوة 2: المعدّل والثوابت يحدّدان الأداء العملي. النتيجة: اسأل «بأيّ معدّل؟» لا «هل يتقارب؟». الربط بالذكاء الاصطناعي: هذا هو الفرق بين النظرية والممارسة في تعلّم الآلة.

مثال (30.7-14): الانحياز الاستقرائي بوصفه الحلّ المعطيات: مهمة رؤية، نختار شبكة التفافية. المطلوب: التبرير من منظور NFL. الحل: الخطوة 1: التماثل الانتقالي للصور انحيازٌ يقيّد $\mathcal{H}$ إلى دوالّ ثابتة بالانتقال. الخطوة 2: هذا التقييد يقلّل السعة الفعّالة بمراتب دون فقدان الحقيقة. النتيجة: الانحياز الصحيح = تقليص فضاء البحث إلى ما يحتوي الحلّ. الربط بالذكاء الاصطناعي: المبدأ ذاته في المحوّلات (الفصل 39) والشبكات البيانية (43).

مثال (30.7-15): النتيجة العملية الجامعة المعطيات: مشروع جديد ببيانات محدودة. المطلوب: ماذا تفعل نظرية NFL عمليّاً؟ الحل: الخطوة 1: ابحث عن بنية المسألة (تماثلات، سلاسة، تناثر، سببية). الخطوة 2: عبّر عنها في المعمارية والتنظيموتكثير البيانات. الخطوة 3: لا تراهن على «خوارزمية سحرية» عامّة. النتيجة: المعرفة بالمجال = تقليص فضاء الفرضيات = تعلّم أسرع. الربط بالذكاء الاصطناعي: أقوى نتيجة عملية في هذا الفصل.

أخطاء شائعة

- الاستشهاد بـ NFL للقول إنّ «كلّ النماذج سواء» (هي تقول: على كلّ المسائل الممكنة فقط).
- الخلط بين الاتساق والمعدّل (الأخير هو ما يهمّ عمليّاً).
- افتراض التقارب الموحّد لفضاءات غير منتهية بلا قياس سعة مناسب (الفصل 31).
- نسيان أنّ الانحياز الاستقرائي ضروري لا اختياري.
- تثبيت k أو λ مع نموّ البيانات.

المبرهنة (تفكيك ثلاثي للخطر الزائد): لتكن h_S حلّاً exact لـ ERM داخل $\mathcal{H}$، و $\hat{h}$ ما أعاده المُحسِّن فعلاً. فإنّ

$$R(\hat{h}) - R^\star = \underbrace{\left(\inf_{h\in\mathcal{H}} R(h) - R^\star\right)}_{\text{تقريب approximation}} + \underbrace{\left(R(h_S) - \inf_{h\in\mathcal{H}} R(h)\right)}_{\text{تقدير estimation}} + \underbrace{\left(R(\hat{h}) - R(h_S)\right)}_{\text{تحسين optimisation}} \tag{21.30}$$

وكلّ حدّ غير سالب، وكلّ منها يُعالَج بعلاج مختلف:

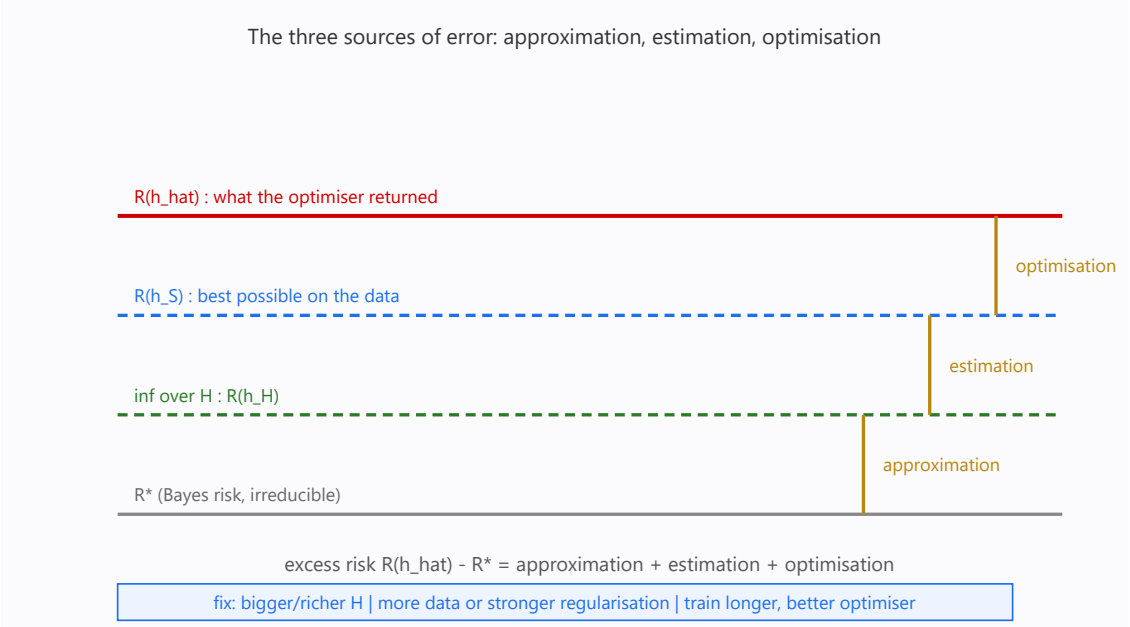
(22.30) بوقت/مُحسِّن أفضل $\downarrow$ تحسين ; أو سعة أصغر $\uparrow n$ ب $\downarrow$ تقدير ; أوسع $\mathcal{H}$ ب $\downarrow$ تقريب

جدول الرموز

الرمز	المعنى	ملاحظة
تقريب	قصور $\mathcal{H}$ عن الحقيقة	يُقاس بخطأ تدريب مرتفع
تقدير	قصور n	يُقاس بفجوة التدريب–الاختبار
تحسين	قصور المُحسِّن	يُقاس بعدم التقلّص/التذبذب
h_S	الحلّ النظري لـ ERM	قد لا نبلغه عدديّاً
$\hat{h}$	ما نملكه فعلاً	موضوع التقويم

الرسم

<figure> الشكل<figcaption> 7.30: الخطر الزائد = تقريب + تقدير + تحسين؛ ولكلّ مصدر علاج مختلف،



شكل ٧.٣٠: *
تفكيك الخطر الزائد إلى ثلاثة مصادر

والتشخيص الخاطئ يهدر الموارد.</figcaption> </figure>

البرهان

الخطوة 1: بإضافة وطرح $\inf_{\mathcal{H}} R$ و $R(h_S)$:

$$R(\hat{h}) - R^\star = \big(R(\hat{h}) - R(h_S)\big) + \big(R(h_S) - \inf_{\mathcal{H}} R\big) + \big(\inf_{\mathcal{H}} R - R^\star\big)$$

الخطوة 2 (عدم السلبية): الحدّ الأوّل $0 \geq$ لأنّ h_S يقلّل الخطر بين... (تنبيه: h_S يقلّل **الخطر التجريبي** لا الخطر؛ والحدّ الأوّل غير سالب **بالمتوسط** أو بشرط نجاح التحسين؛ عمليّاً يُقرأ بوصفه «خسارة ما بلغناه من سوء التحسين»). والحدّان الآخران غير سالبين بتعريف inf. ■

الخطوة 3 (استقلال العلاجات): توسيع $\mathcal{H}$ يقلّل التقريب وقد يزيد التقدير؛ زيادة n تقلّل التقدير فقط؛ وتحسين المُحسِّن يقلّل التحسين فقط $\Rightarrow$ لا يوجد إجراء واحد يقلّل الثلاثة معاً. ■

خمسة عشر مثالاً محلولاً

مثال (30.8-1): حصيلة رقمية المعطيات: تقريب $0.05 =$، تقدير $0.03 =$، تحسين $0.02 =$، $R^\star = 0.02$. المطلوب: الخطر الكلي. الحل: الخطوة 1: الخطر الزائد $0.10 = 0.02 + 0.03 + 0.05 =$. الخطوة 2: $R(\hat{h}) = 0.02 +$ $0.12 = 0.10$. النتيجة: نصف الخطأ من التقريب $\Rightarrow$ الهدف الأول هو السعة لا البيانات. الربط بالذكاء الاصطناعي: حساب العائد قبل إنفاق الموارد.

مثال (30.8-2): هيمنة التقريب المعطيات: خطأ تدريب $0.30 =$ وخطأ تحقّق $0.31 =$. المطلوب: التشخيص. الحل: الخطوة 1: الفجوة صغيرة (0.01) $\Rightarrow$ التقدير ليس المشكلة. الخطوة 2: الخطأ المطلق مرتفع $\Rightarrow$ التقريب يهيمن. النتيجة: زِد سعة النموذج أو حسّن الخصائص. الربط بالذكاء الاصطناعي: علامة التفريط في الملاءمة الكلاسيكية.

مثال (30.8-3): هيمنة التقدير المعطيات: خطأ تدريب $0.02 =$ وخطأ تحقّق $0.25 =$. المطلوب: التشخيص. الحل: الخطوة 1: فجوة $0.23 \Rightarrow$ التقدير يهيمن. النتيجة: زِد البيانات أو شدّد التنظيم أو قلّل السعة. الربط بالذكاء الاصطناعي: علامة الإفراط في الملاءمة الكلاسيكية.

مثال (30.8-4): هيمنة التحسين المعطيات: شبكة كبيرة، خطأ التدريب يتذبذب حول 0.40 ولا يهبط. المطلوب: التشخيص. الحل: الخطوة 1: خطأ التدريب مرتفع رغم سعة كبيرة $\Rightarrow$ ليس تقريباً. الخطوة 2: الفجوة عن التحقّق صغيرة $\Rightarrow$ ليس تقديراً. الخطوة 3: إذن التحسين هو المشكلة (معدّل خطوة، تطبيع، تهيئة). النتيجة: أصلح المُحسِّن قبل تغيير المعمارية. الربط بالذكاء الاصطناعي: خطأ شائع: «الشبكة صغيرة» بينما الخلل في معدّل التعلّم.

مثال (30.8-5): منحنى التعلّم أداة تشخيص المعطيات: أخطاء التحقّق عند $1k, 4k, 16k$: $n =$ $0.28, 0.22, 0.20$. المطلوب: التوقّع عند $n = 64k$. الحل: الخطوة 1: التحسّن يتباطأ: -0.06 ثمّ $-0.02 \Rightarrow$ يقترب من أرضية. الخطوة 2: التوقّع $0.185 \approx 0.19-$. النتيجة: الأرضية هي حدّ التقريب $\Rightarrow$ مزيد من البيانات لن ينفع كثيراً. الربط بالذكاء الاصطناعي: منحنى التعلّم أهمّ أداة لتخصيص ميزانية البيانات.

مثال (30.8-6): جدول التشخيص السريع المعطيات: (تدريب، تحقّق) = (مرتفع، مرتفع). المطلوب: التشخيص والعلاج. الحل: الخطوة 1: تقريب $\Rightarrow$ وسّع $\mathcal{H}$، حسّن الخصائص، أضف تمثيلاً أفضل. النتيجة: التنظيم هنا يضرّ. الربط بالذكاء الاصطناعي: كثيرة هي الحالات التي يُضاف فيها تنظيم لمشكلة هي في الأصل تفريط.

مثال (30.8-7): (تدريب، تحقّق) = (منخفض، مرتفع) المعطيات: الفجوة كبيرة. المطلوب: العلاج. الحل: الخطوة 1: تقدير $\Rightarrow$ بيانات أكثر، تنظيم أقوى، توقّف مبكر، تجميع. النتيجة: توسيع النموذج هنا يضرّ. الربط بالذكاء الاصطناعي: الحالة الأشهر في المسائل قليلة البيانات (طبية، قانونية).

مثال (30.8-8): متى تضرّ السعة رغم هيمنة التقريب المعطيات: شبكة ضخمة لا تُدرَّب جيّداً بسبب موارد محدودة. المطلوب: القرار. الحل: الخطوة 1: توسيع $\mathcal{H}$ يقلّل التقريب لكن يرفع خطأ التحسين في الميزانية المتاحة. الخطوة 2: الأفضل نموذج متوسط يمكن تدريبه حتى التقارب. النتيجة: الأمثلية مقيدة بالميزانية الحسابية لا بالنظرية فقط. الربط بالذكاء الاصطناعي: يفسّر نجاح النماذج «المناسبة للميزانية» في التطبيق الصناعي.

مثال (30.8-9): تخصيص الميزانية المعطيات: ميزانية ثابتة: بيانات أكثر أم نموذج أكبر؟ المطلوب: القاعدة. الحل: الخطوة 1: قِس الحدّين: إن كان التقريب $\gg$ التقدير فالنموذج أوّلاً. الخطوة 2: وإن كان العكس فالبيانات أوّلاً. النتيجة: قرارٌ مبنيّ على قياس لا على حدس. الربط بالذكاء الاصطناعي: أساس «قوانين التوسّع» (scaling laws) الحديثة.

مثال (30.8-10): قوانين التوسّع المعطيات: خسارة الاختبار $C n^{-\alpha} \approx$ بـ $\alpha = 0.3$. المطلوب: أثر مضاعفة البيانات 10 مرّات. الحل: الخطوة 1: $0.501 = 10^{-0.3} \Rightarrow$ الخسارة تصير النصف تقريباً. النتيجة: عوائد قويّة لكن متناقصة (ليست $10\times$ تحسّناً). الربط بالذكاء الاصطناعي: إطار كمّي لمنحنيات التعلّم في المحوّلات (الفصل 39).

مثال (30.8-11): الهبوط المزدوج (double descent) المعطيات: زيادة السعة بعد نقطة الاستيعاب (interpolation) المطلوب: ما المتوقّع؟ الحل: الخطوة 1: المنحنى الكلاسيكي يتوقّع تدهوراً مستمراً. الخطوة 2: عملياً كثيراً ما يهبط الخطأ مجدّداً بعد تجاوز السعة نقطة «الاستيعاب التامّ» للبيانات. النتيجة: منحنى الخطر قد يكون على شكل «هبوط مزدوج» لا U بسيط. الربط بالذكاء الاصطناعي: هذه الظاهرة موضوع الفصل 34 (حدود التعميم في الشبكات العميقة).

مثال (30.8-12): نظام الاستيعاب (interpolation) المعطيات: نموذج بلغ خطأ تدريب $0 =$ ولا يزال يعمّم جيّداً. المطلوب: التفسير. الحل: الخطوة 1: «حفظ البيانات» لا يعني بالضرورة تعميماً سيّئاً في الأبعاد العالية. الخطوة 2: الانحياز الضمني للمُحسِّن يختار من الحلول المطابقة «الأبسط». النتيجة: السعة وحدها لا تحدّد التعميم؛ طريقة البحث في $\mathcal{H}$ تحدّده أيضاً. الربط بالذكاء الاصطناعي: أحد أكبر أسئلة النظرية المعاصرة (الفصلان 34 و 40).

مثال (30.8-13): متى تزيد البيانات المعطيات: فجوة التدريب–الاختبار $0.15 =$، خطأ التدريب $0.03 =$. المطلوب: القرار. الحل: الخطوة 1: التقدير يهيمن $\Rightarrow$ زد البيانات أو التنظيم. النتيجة: توقّع تحسّن بمعدّل $1/\sqrt{n} \approx$ في الفجوة. الربط بالذكاء الاصطناعي: حال الـ90% من مشاريع البيانات الصغيرة.

مثال (30.8-14): متى تزيد السعة المعطيات: خطأ التدريب $0.35 =$، الفجوة $0.02 =$، المُحسِّن متقارب. المطلوب: القرار. الحل: الخطوة 1: التقريب يهيمن $\Rightarrow$ وسّع النموذج أو غيّر التمثيل. النتيجة: التنظيم سيضرّ؛ والتدريب الأطول لن ينفع. الربط بالذكاء الاصطناعي: حال النماذج البسيطة على بيانات غنيّة (رؤية، صوت).

مثال (30.8-15): متى تطيل التدريب المعطيات: خطأ التدريب ما زال يهبط عند انتهاء الميزانية، والفجوة صغيرة. المطلوب: القرار. الحل: الخطوة 1: التحسين يهيمن $\Rightarrow$ أطل التدريب، حسّن المُحسِّن، اضبط معدّل التعلّم. النتيجة: لا تغيّر المعمارية قبل التأكّد من التقارب. الربط بالذكاء الاصطناعي: قاعدة ذهبية في الممارسة: تأكّد من التقارب أوّلاً.

أخطاء شائعة

- علاج الإفراط بالتقريب والعكس (أي تطبيق تنظيم على نموذج مقصّر).
- قراءة خطأ التدريب وحده أو خطأ الاختبار وحده (الاثنان معاً هما التشخيص).
- افتراض أنّ «المزيد من البيانات» يحلّ كلّ شيء.
- تجاهل خطأ التحسين واعتبار كلّ فجوة «تقديراً».
- تغيير عدّة أشياء معاً ثمّ العجز عن attribution النتيجة.

ملخّص النظريات

النظرية	المفهوم	الأهمّية
30.2 إطار التعلّم	R مقابل $\hat{R}$	تعريف رسمي لمسألة التعلّم
30.3 التقارب الموحّد و SRM	$\sqrt{\ln(2\|H\|/\delta)/2n}$	ضمان تعميم واختيار سعة
30.4 التحيز–التباين	$\text{Bias}^2 + \text{Var} + \sigma^2$	تفسير الإفراط والتفريط
30.5 التنظيم	$\min \hat{R} + \lambda\Omega$	التحكم في السعة عملياً
30.6 التحقق المتقاطع	(30.15)–(30.18)	اختيار نموذج بلا تسرّب
30.7 الاتساق و NFL	(30.19) و (30.20)	حدود الممكن وضرورة الانحياز
30.8 الأخطاء الثلاثة	تقريب + تقدير + تحسين	خريطة تشخيص وتخصيص موارد

عشرون تمريناً (مع إجابات مختصرة)

١. تعريف الخطر؟ ($R(h) = \mathbb{E}[\ell(h(x), y)]$)

٢. تعريف الخطر التجريبي؟ ($\hat{R} = \frac{1}{n}\sum \ell$)

٣. ما ERM؟ ($\arg\min_{h \in \mathcal{H}} \hat{R}(h)$)

٤. ما خطر بايز؟ ($\inf_h R(h)$ على كلّ الدوالّ)

٥. لماذا الخطر التجريبي متفائل؟ (لأنّ $\hat{h}$ اختير ليقلّله)

٦. حدّ التقارب الموحّد لفضاء منتهٍ؟ ($\sqrt{\ln(2|H|/\delta)/2n}$)

٧. كيف يتغيّر الحدّ مع n؟ ($1/\sqrt{n}$)

٨. ومع $|H|$؟ ($\sqrt{\ln |H|}$ — لوغاريتمي)

٩. ماذا يختار SRM؟ (أصغر حدّ: $\hat{R} + \Omega$)

١٠. تفكيك التحيز–التباين؟ ($\text{Bias}^2 + \text{Var} + \sigma^2$)

١١. هل ينطبق حرفياً على خسارة 0-1؟ (لا)

١٢. حلّ الحيد المغلق؟ ($(X^\top X + \lambda I)^{-1} X^\top y$)

١٣. لماذا L1 ينتج تناثراً؟ (زوايا المعيّن وشرط KKT)

١٤. حدّ التحقّق عند اختيار أفضل K؟ ($\sqrt{\ln(2K/\delta)/2m}$)

١٥. لماذا CV متشائم؟ (يُدرَّب على $n(1 - 1/k)$)

١٦. متى يكون ERM متّسقاً؟ (عند التقارب الموحّد)

١٧. ماذا تقول NFL؟ (تساوي الأداء بالمتوسط على كلّ المسائل)

١٨. ما مصدر الخطأ الأول في (21.30)؟ (التقريب = قصور $\mathcal{H}$)

١٩. علامة هيمنة التقدير؟ (فجوة كبيرة بين التدريب والتحقّق)

٢٠. علامة هيمنة التحسين؟ (خطأ تدريب مرتفع مع سعة كافية وعدم تقارب)

فهرس الرموز

الرمز	المعنى
R, $\hat{R}$	الخطر والخطر التجريبي
$R^\star$	خطر بايز
$\mathcal{H}$	فضاء الفرضيات
ε	هامش التقارب الموحّد
Ω, λ	العقوبة وقوّة التنظيم
Bias^2, Var	مربع التحيز والتباين
$\widehat{R}_{CV}$	مقدّر التحقق المتقاطع
K, k	عدد المرشّحين وعدد الأضعاف

مراجع

- Vapnik — *Theory Learning Statistical* و *Theory Learning Statistical of Nature The* (SRM).
- Ben-David & Shalev-Shwartz — *Learning Machine Understanding* (الإطار الحديث والحدود).
- Friedman & Tibshirani Hastie, — *Learning Statistical of Elements The* (التحيز–التباين والتنظيم).
- Talwalkar & Rostamizadeh Mohri, — *Learning Machine of Foundations* (حدود التعميم والتحقق).
- Macready & Wolpert — «No Free Lunch Theorems for Optimization» (1997).
- Wolpert — «The Lack of A Priori Distinctions Between Learning Algorithms» (1996).
- Domingos — «A Unfiied Bias-Variance Decomposition» (2000).
- Doursat & Bienenstock Geman, — «Neural Networks and the Bias/Variance Dilemma» (1992).

خاتمة: أعطانا هذا الفصل الإطار والحدود الأولى، لكنّه ترك سؤالاً معلّقاً: ماذا نفعل حين يكون $\mathcal{H}$ **غير منتهٍ** — كما في كلّ نموذج حقيقي؟ الإجابة تحتاج مقياساً للسعة لا يعتمد على عدد العناصر: **بُعد VC** ومتراجحاتٌ Rademacher، وهو موضوع **الفصل 31.**

بُعد VC، متراجحات Rademacher، والتركيز

«السعة ليست عددَ الفرضيات؛ إنّها عددُ الوسوم التي تستطيع فرضيّاتك اصطناعها.»

الفصل 30 ترك سؤالاً معلّقاً: حدوده (6.30) تتطلّب فضاء فرضيات **منتهياً**، بينما كلّ نموذج حقيقي — خطّي في $\mathbb{R}^{100}$، شبكة عصبية، آلة نووية — فضاؤه غير منتهٍ. هذا الفصل يجيب: السعة التي تهمّ ليست عدد العناصر بل **عدد الوسوم الممكنة** على m نقطة، وهذا يقود إلى **بُعد VC**. ثمّ ننتقل إلى مقاييس أدقّ تعتمد على البيانات نفسها (تعقيد Rademacher) وعلى هندسة الفضاء (أرقام التغطية ومتراجحة Dudley)، ونختم بحدود الهامش التي تفسّر نجاح الآلات النووية، وبحساب سعة الشبكات العصبية الذي يمهّد للفصل 34.

سبع نظريات:

- **2.31 التحطيم (shattering) وبُعد VC** — مقياس السعة الحقيقي.
- **3.31 متراجحة Sauer–Shelah ودالّة النموّ** — لماذا يصير النموّ كثير حدود؟
- **4.31 مبرهنة التأسيس: حدّ التعميم ببُعد VC** — من السعة إلى الضمان.
- **5.31 تعقيد Rademacher** — حدود تعتمد على البيانات.
- **6.31 أرقام التغطية ومتراجحة Dudley** — السعة بوصفها هندسة.
- **7.31 حدود الهامش** — لماذا تنجح الآلات النووية في أبعاد لانهائية؟
- **8.31 سعة الشبكات العصبية** — أرقام صادمة تمهّد للفصل 34.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
$S = \{x_1, \dots, x_m\}$	مجموعة نقاط	بلا وسوم
$h\|_S$	تقييد الفرضية h على S	متّجه وسوم في $\{0,1\}^m$
تحطيم (shatter)	$\mathcal{H}$ تحقّق كلّ 2^m وسماً على S	
$\Pi_{\mathcal{H}}(m)$	دالّة النموّ	عدد الوسوم الممكنة
d_{VC} أو d	بُعد فابنيك–تشرونِنكِس	أكبر m يُحطَّم
$\mathfrak{R}_n(\mathcal{F})$	تعقيد Rademacher	متوقّع، يعتمد على $\mathcal{D}$
$\hat{\mathfrak{R}}_S(\mathcal{F})$	تعقيد Rademacher التجريبي	يُحسب من العيّنة
σ_i	إشارات رادِماخر عشوائية	± 1 باحتمال $\frac{1}{2}$
$\mathcal{N}(\varepsilon, \mathcal{F}, \|\cdot\|)$	رقم التغطية	أصغر عدد كرات نصف قطرها ε
γ	الهامش	$y\,h(x) \geq \gamma$
$\hat{R}_\gamma(h)$	خطر الهامش التجريبي	نسبة أمثلة هامشها $< \gamma$

الاتفاقيات: نعمل في التصنيف الثنائي $\mathcal{Y} = \{-1, +1\}$ بخسارة 0-1 ما لم نذكر خلاف ذلك؛ والخسائر محدودة بـ $[0,1]$ في الحدود. نرمز $\mathcal{F}$ لفضاء دوالّ حقيقية و $\mathcal{H}$ لفضاء فرضيات؛ والفرق بينهما تقنيّ لا جوهري.

التعريف: لتكن $\mathcal{H}$ عائلةً من الدوالّ $\mathcal{X} \to \{-1,+1\}$ ولمجموعةٍ منتهية $S = \{x_1,\dots,x_m\} \subseteq \mathcal{X}$ نعرّف تقييد $\mathcal{H}$ على S:

$$\mathcal{H}|_S \;=\; \big\{(h(x_1),\dots,h(x_m)) : \; h \in \mathcal{H}\big\} \;\subseteq\; \{-1,+1\}^m \tag{1.31}$$

نقول إنّ $\mathcal{H}$ **تحطم** S إذا كان $|\mathcal{H}|_S| = 2^m$ (تحقّق كلّ الوسوم الممكنة). و

$$d_{\mathrm{VC}}(\mathcal{H}) \;=\; \max\big\{m : \; \exists S,\; |S| = m,\; \mathcal{H} \text{ تحطم } S\big\} \tag{2.31}$$

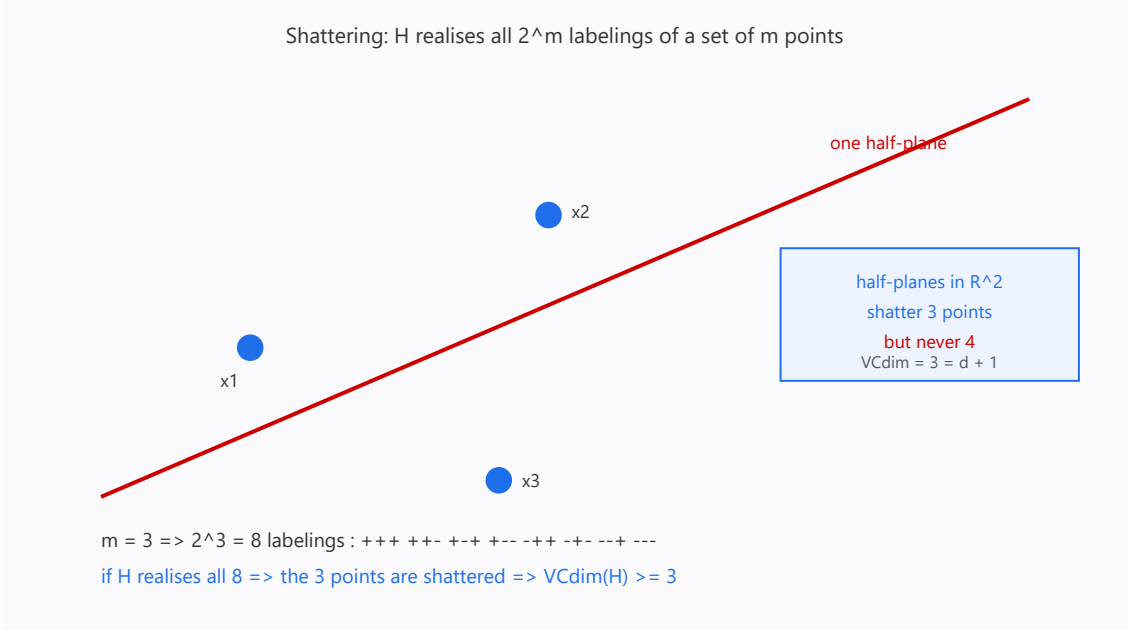
مع $d_{\mathrm{VC}} = \infty$ إذا حطمت $\mathcal{H}$ مجموعات كبيرة كيفما شئنا.

جدول الرموز

الرمز	المعنى	ملاحظة
$\mathcal{H}\|_S$	بصمة الفرضيات على S	مجموعة وسوم
تحطيم	$\lvert\mathcal{H}\|_S\rvert = 2^m$	أقصى تنوّع ممكن
2^m	عدد الوسوم الممكنة على m نقطة	
d_{VC}	أكبر حجم يُحطَم	مقياس السعة
لا يعتمد على التوزيع	خصائص تركيبية بحتة	قوّة وضعف معاً
∞	سعة لانهائية	لا ضمان بلا هامش/تنظيم

الرسم

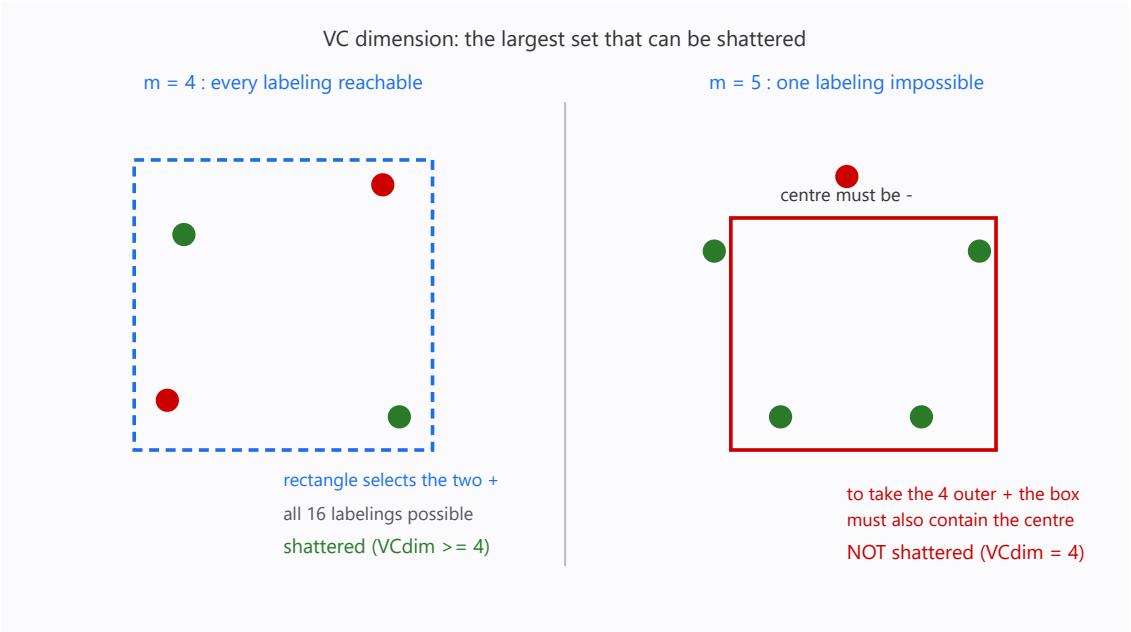
<figure> الشكل<figcaption> 1.31: ثلاث نقاط في المستوى تُحطَم بنصف المستويات (ثمانية وسوم كلّها ممكنة) ⇒



شكل ١.٣١: *
التحطيم وبعد VC

$d_{\mathrm{VC}} \ge 3$، وأربع نقاط لا تُحطَم أبداً ⇒ $d_{\mathrm{VC}} = 3$.</figcaption></figure>

<figure> الشكل<figcaption> 2.31: المستطيلات المحورية تحطم أربع نقاط ولا تحطم خمساً ⇒ $d_{\mathrm{VC}} = 4$.</figcaption></figure>



شكل ٢.٣١: *
بعد VC للمستطيلات المحورية

البرهان

الخطوة 1 (التحطيم خصيصة تركيبية): $|\mathcal{H}|_S|$ يعتمد على مواضع النقاط، لكنّ وجود مجموعة محطومة من حجم m يعتمد على بنية $\mathcal{H}$ وحدها.

الخطوة 2 (لماذا لا تُحطَم 4 نقاط بنصف مستويات في $\mathbb{R}^2$): لأيّ أربع نقاط إمّا أن تكون إحداها داخل المثلّث المحدد بالثلاث الأخرى (فلا يمكن فصلها وحدها)، وإمّا أن تكون على شكل رباعي محدّب فوسم «القطران موجبان والآخران سالبان» غير قابل للفصل بخطّ مستقيم. $\Rightarrow d_{\mathrm{VC}} = 3$.

الخطوة 3 (نصف فضاءات في $\mathbb{R}^d$): بُعدها $d + 1$ بالإحداثيات المتجانسة: تُحطَم $d + 1$ نقطة في وضع عام (مبسّط)، ولا تُحطَم $d + 2$ نقطة (بمبرهنة رادون: كلّ $d + 2$ نقطة في $\mathbb{R}^d$ تقبل تجزيئاً إلى مجموعتين متقاطعَين في الأغماد المحدّبة). ■

الخطوة 4 (خصائص أساسية): (أ) الرتابة: $\mathcal{H}' \subseteq \mathcal{H} \Rightarrow d_{\mathrm{VC}}(\mathcal{H}') \le d_{\mathrm{VC}}(\mathcal{H})$. (ب) d_{VC} لا يعتمد على $\mathcal{D}$. (ج) $d_{\mathrm{VC}} = \infty$ لا يعني «لا تعميم» بل «لا ضمان من هذا النوع». ■

خمسة عشر مثالاً محلولاً

مثال (1-2.31): الفترات على الخطّ الحقيقي المعطيات: $\mathcal{H} = \{x \mapsto +1 \text{ إذا } a \le x \le b\}$. المطلوب: d_{VC}. الحل: الخطوة 1: نقطتان $x_1 < x_2$: الوسوم الأربعة ممكنة (++ بفترة كبيرة، −− بفترة خارجية، +− بفترة $[x_1, x_2)$ تقريباً، −+ بفترة تحتوي x_2 فقط). الخطوة 2: ثلاث نقاط: الوسم $+, -, +$ يحتاج فترتين $\Rightarrow$ غير ممكن. النتيجة: $d_{\mathrm{VC}} = 2$. الربط بالذكاء الاصطناعي: أصغر «عتبة مزدوجة» في كشف الشذوذ (مثل نطاق الحرارة الطبيعي).

مثال (2-2.31): نصف المستويات في $\mathbb{R}^2$ المعطيات: مصنّف خطّي ثنائي الأبعاد. المطلوب: d_{VC}. الحل: الخطوة 1: ثلاث نقاط في وضع عام تُحطَم (8 وسوم كلّها بخطوط). الخطوة 2: أربع نقاط لا تُحطَم (مبرهنة رادون). النتيجة: $d_{\mathrm{VC}} = 3 = d + 1$. الربط بالذكاء الاصطناعي: مصنّف خطّي على خصيصتين (مثل ضغط الدم والسكر).

مثال (31.2-3): نصف فضاءات في $\mathbb{R}^{10}$ المعطيات: انحدار لوجستي على 10 خصائص. المطلوب: d_{VC}. الحل: الخطوة 1: $d_{\text{VC}} = d + 1 = 11$. النتيجة: السعة خطّية في البعد — لا تتضاعف معه. الربط بالذكاء الاصطناعي: تبرير كمّي لنجاح النماذج الخطّية في أبعاد متوسّطة.

مثال (31.2-4): المستطيلات المحورية في $\mathbb{R}^2$ المعطيات: $\{\ \} = \mathcal{H}$مستطيلات محاورها موازية للمحاور{. المطلوب: d_{VC}. الحل: الخطوة 1: أربع نقاط على شكل «+» تُحطَّم (كلّ وسم بمستطيل مناسب). الخطوة 2: خمس نقاط: وسم «الأطراف موجبة والوسط سالب» غير ممكن. النتيجة: $d_{\text{VC}} = 4 = 2d$. الربط بالذكاء الاصطناعي: قواعد «نطاقات» في أنظمة كشف التسلّل (منفذ × مدة).

مثال (31.2-5): اتحاد k فترات المعطيات: $\{\ \} = \mathcal{H}$اتحاد k فترات على $\{\mathbb{R}$. المطلوب: d_{VC} عند $k = 3$. الحل: الخطوة 1: لكلّ فترة معلمان $\Rightarrow 2k$ معلمة. الخطوة 2: $d_{\text{VC}} = 2k = 6$. النتيجة: السعة تنمو خطّياً مع عدد الفترات. الربط بالذكاء الاصطناعي: نوافذ زمنية متعددة في كشف الأعطال الصناعية.

مثال (31.2-6): جذوع القرار (decision stumps) في بعد واحد المعطيات: $\mathcal{H} = \{x \mapsto \text{sign}(x-\theta) : \theta \in \{\mathbb{R}\} \cup \{x \mapsto -\text{sign}(x-\theta)\}$. المطلوب: d_{VC}. الحل: الخطوة 1: نقطتان تُحطَمان (الأربعة وسوم: $+ +$ ، $- -$، $+ -$، $- +$ بالاتجاهين). الخطوة 2: ثلاث نقاط: الوسم $+, -, +$ غير ممكن بجذع واحد. النتيجة: $d_{\text{VC}} = 2$. الربط بالذكاء الاصطناعي: الوحدة الأساسية في التعزيز (AdaBoost) — سعتها أصغر ما يمكن.

مثال (31.2-7): فئة المنفردات (singletons) المعطيات: $\mathcal{H} = \{h_a : h_a(x) = +1$ إذا $x = a\}$ على فضاء غير منتهٍ. المطلوب: d_{VC}. الحل: الخطوة 1: نقطة واحدة تُحطَم (وسم $+$ بـ h_a ووسم $-$ بأيّ $h_{a'}$). الخطوة 2: نقطتان: الوسم $+, +$ غير ممكن. النتيجة: $d_{\text{VC}} = 1$ رغم أنّ $|\mathcal{H}| = \infty$. الربط بالذكاء الاصطناعي: دليل مباشر على أنّ عدد المعلمات $\neq$ السعة.

مثال (31.2-8): المضلّعات المحدّبة في $\mathbb{R}^2$ المعطيات: $\{\ \} = \mathcal{H}$ كلّ المضلّعات المحدّبة{. المطلوب: d_{VC}. الحل: الخطوة 1: لأيّ m نقطة على دائرة، كلّ وسم ممكن بمضلّع يمرّ برؤوسها. الخطوة 2: إذن تُحطَم مجموعات كبيرة كيفما شئنا. النتيجة: $d_{\text{VC}} = \infty$. الربط بالذكاء الاصطناعي: نماذج «قابلة للتشكّل الحرّ» بلا ضمان تعميم من هذا النوع.

مثال (31.2-9): أقرب الجيران بـ $k = 1$ المعطيات: مصنّف 1-NN على فضاء متّصل. المطلوب: d_{VC}. الحل: الخطوة 1: يمكن لـ 1-NN تحقيق أيّ وسم على أيّ مجموعة منتهية (كلّ نقطة تصنَّف بوسم أقرب جار لها = نفسها). النتيجة: $d_{\text{VC}} = \infty$ — ومع ذلك يعمل 1-NN جيّداً! الربط بالذكاء الاصطناعي: مثال حاسم: السعة اللانهائية لا تعني الفشل، بل تعني أنّ حدود هذا الفصل لا تكفي.

مثال (31.2-10): عائلة الجيوب المعطيات: $\mathcal{H} = \{x \mapsto \text{sign}(\sin(\omega x)) : \omega > 0\}$. المطلوب: d_{VC}. الحل: الخطوة 1: باختيار ω كبيرة نحقّق أيّ وسم على أيّ عدد من النقاط المتميّزة. النتيجة: $d_{\text{VC}} = \infty$ بمعلمة واحدة فقط! الربط بالذكاء الاصطناعي: تحذير: «معلمة واحدة = سعة صغيرة» استدلال خاطئ تماماً.

مثال (31.2-11): المصنّفات الخطّية المارّة بالأصل المعطيات: $\mathcal{H} = \{x \mapsto \text{sign}(w^\top x)\}$ بلا حدّ (bias) في $\mathbb{R}^d$. المطلوب: d_{VC}. الحل: الخطوة 1: إزالة الحدّ تقلّص السعة بمقدار واحد: $d_{\text{VC}} = d$. النتيجة: قيدٌ بسيط أنقص البعد بواحد. الربط بالذكاء الاصطناعي: أثر بنيوي صغير يمكن قياسه بدقّة.

مثال (31.2-12): SVM بنواة غاوسية المعطيات: $k(x, x') = \exp(-\|x - x'\|^2/2\sigma^2)$. المطلوب: d_{VC}. الحل: الخطوة 1: فضاء المُدخلات ضخم أو لانهائي البعد. الخطوة 2: باختيار σ صغير نفصل أيّ وسم $\Rightarrow d_{\text{VC}} = \infty$. النتيجة: ومع ذلك تنجح هذه النماذج عملياً $\Rightarrow$ نحتاج حدود الهامش (31.7). الربط بالذكاء الاصطناعي: أشهر مثال على تجاوز حدود السعة للنجاح العملي.

مثال (31.2-13): شبكة عصبية بعدد أوزان W المعطيات: شبكة بوحدات ترجيح (threshold) و W أوزان و L طبقات. المطلوب: حدود d_{VC}. الحل: الخطوة 1: حدّ سفلي: $d_{\text{VC}} \geq W$ (تبني وسم 2^W). الخطوة 2: حدّ علوي

معروف: $d_{\text{VC}} = O(WL\log W)$ للشبكات القطعية الخطّية (ReLU). النتيجة: السعة أكبر من عدد الأوزان لكن ليست أسّية فيه. الربط بالذكاء الاصطناعي: الأساس الكمّي لمفارقة الشبكات الضخمة (8.31 والفصل 34).

مثال (14-2.31): فضاء كلّ الدوالّ على فضاء منته المعطيات: $|\mathcal{X}| = N$ و $\mathcal{H} = \{-1,+1\}^{\mathcal{X}}$. المطلوب: d_{VC}. الحل: الخطوة 1: كلّ الوسوم على $\mathcal{X}$ كلّه ممكنة (2^N). الخطوة 2: ولا توجد مجموعة أكبر من $\mathcal{X}$. النتيجة: $d_{\text{VC}} = N$ — يعيدنا إلى حدّ الفصل 30 بـ $|\mathcal{H}| = 2^N$. الربط بالذكاء الاصطناعي: تحقّق من اتّساق النظريتين عند انتهاء الفضاء.

مثال (15-2.31): كم نقطة نحتاج لإثبات $d_{\text{VC}} \geq 4$؟ المعطيات: نريد إثبات أنّ فضاءً ما يحطم 4 نقاط. المطلوب: عدد الوسوم الواجب التحقّق منها. الحل: الخطوة 1: التحطيم يعني تحقيق كلّ الوسوم: $2^4 = 16$. الخطوة 2: عملياً نبحث عن ترتيب هندسي يسمح بها كلّها (لا نجرّبها واحدة واحدة). النتيجة: التحطيم خاصية «مرّة واحدة» لا اختبار إحصائي. الربط بالذكاء الاصطناعي: لهذا يُحسب d_{VC} تحليلياً لا تجريبياً.

أخطاء شائعة

- الخلط بين عدد المعلمات وبُعد VC (قد يكونان مختلفين بمراتب، كما في 10-2.31).
- الظنّ أنّ $d_{\text{VC}} = \infty$ يعني عدم إمكان التعلّم (يعني فقط عدم كفاية هذه الحدود).
- نسيان أنّ d_{VC} لا يعتمد على توزيع البيانات (فراداه لا تُستغلّ).
- حساب d_{VC} على نقاط في «وضع عام» ثمّ تعميم النتيجة على كلّ الترتيبات الخطّية.
- استخدام d_{VC} لمقارنة نماذج من عائلات مختلفة بلا النظر للهامش والضجيج.

المبرهنة: عرّف دالّة النموّ

$$\Pi_{\mathcal{H}}(m) = \max_{S:|S|=m} \left|\mathcal{H}|_S\right| \tag{3.31}$$

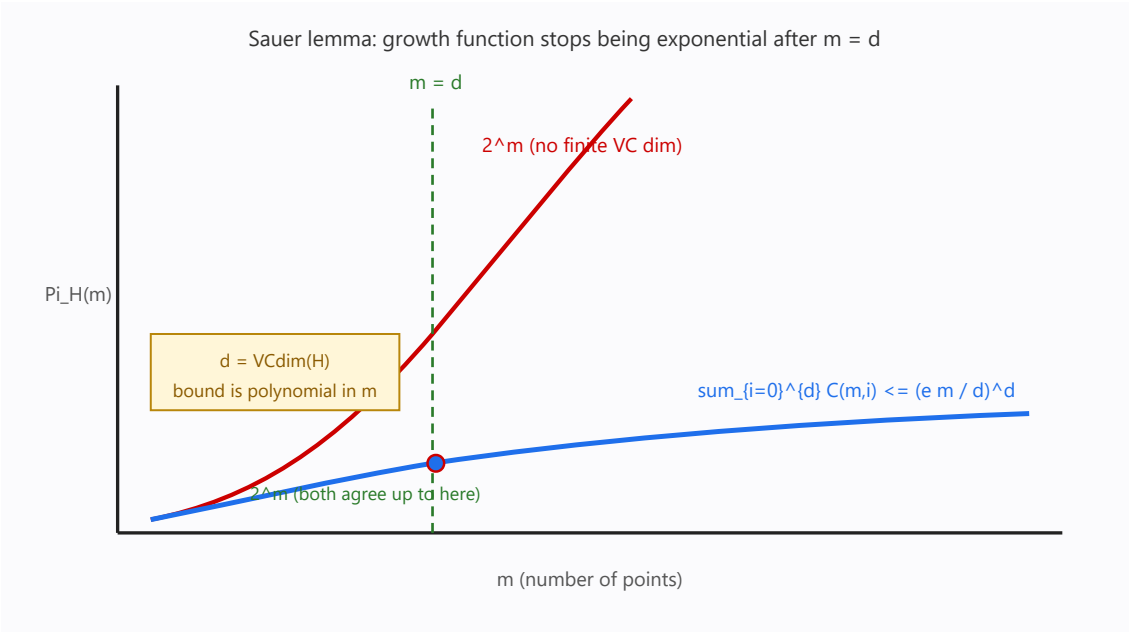
فإذا كان $d_{\text{VC}}(\mathcal{H}) = d < \infty$:

$$\Pi_{\mathcal{H}}(m) \leq \sum_{i=0}^{d} \binom{m}{i} \leq \left(\frac{em}{d}\right)^d \qquad (m \geq d) \tag{4.31}$$

أي أنّ عدد الوسوم الممكنة يتوقّف عن النموّ الأسّي بعد $m = d$ ويصير **كثير حدود** من درجة d.

جدول الرموز

الرمز	المعنى	ملاحظة
$\Pi_{\mathcal{H}}(m)$	أقصى عدد وسوم على m نقطة	$\leq 2^m$ دائماً
$\sum_{i=0}^{d}\binom{m}{i}$	حدّ Sauer الحادّ	يُحقَّق بالمساواة أحياناً
$(em/d)^d$	الصيغة المريحة	فضفاضة لكن سهلة
$m \leq d$	منطقة التحطيم	$\Pi = 2^m$
كثير حدود	جوهر النتيجة	$\Pi(m) = O(m^d)$



شكل ٣١.٣: *
متراجحة Sauer ودالة النمو

الرسم

<figure> الشكل<figcaption> 3.31: تتطابق دالّة النموّ مع 2^m حتى $m = d$، ثمّ تنحني لتصير كثيرة حدود بدرجة d.</figcaption> </figure>

البرهان (مخطّط)

الخطوة 1 (الترميز): بدّل الوسوم $\{-1,+1\}$ بـ $\{0,1\}$؛ وليكن $\mathcal{F} \subseteq \{0,1\}^m$ عائلة وسوم محقَّقة بسعة d.

الخطوة 2 (الحثّ على m): نُقسّم $\mathcal{F}$ إلى $\mathcal{F}_0$ (الوسوم التي تصفُر في الإحداثي الأخير) و $\mathcal{F}_1$. فإنّ $|\mathcal{F}| = |\mathcal{F}_0| + |\mathcal{F}_1|$، و $d_{\mathrm{VC}}(\mathcal{F}_0) \le d$، و $d_{\mathrm{VC}}(\mathcal{F}_1) \le d-1$ (لأنّ تحطيم d إحداثيات في $\mathcal{F}_1$ يستلزم تحطيم $d+1$ في $\mathcal{F}$). بالحثّ: $|\mathcal{F}| \le \sum_{i=0}^{d} \binom{m-1}{i} + \sum_{i=0}^{d-1} \binom{m-1}{i} = \sum_{i=0}^{d} \binom{m}{i}$ بمتطابقة باسكال. ■

الخطوة 3 (الصيغة المريحة): لكلّ $m \ge d$: $\sum_{i=0}^{d} \binom{m}{i} \le \left(\frac{em}{d}\right)^d$ (متراجحة قياسية على المجموع الجزئي لذات الحدّين). ■

الخطوة 4 (الحادّة): الحدّ $\sum_{i=0}^{d} \binom{m}{i}$ حادّ (يُحقَّق مثلاً بفئة الفترات الاتحادية وبنصف الفضاءات). ■

خمسة عشر مثالاً محلولاً

مثال (3.31-1): $d = 2$ و $m = 5$ المعطيات: فضاء بُعده 2. المطلوب: حدّ Sauer. الحل: الخطوة 1: $\binom{5}{0} + \binom{5}{1} + \binom{5}{2} = 1 + 5 + 10 = 16$. النتيجة: من 32 وسماً ممكناً نزلنا إلى 16 كحدّ أعلى. الربط بالذكاء الاصطناعي: نصف السعة الأسّية أُزيل بمعلومتين اثنتين.

مثال (3.31-2): $d = 3$ و $m = 10$ المعطيات: فضاء بُعده 3. المطلوب: الحدّان. الحل: الخطوة 1: $1 + 10 + 45 + 120 = 176$ (حدّ Sauer). الخطوة 2: $(9.06)^3 = 743 = (e \cdot 10/3)^3$ (الصيغة المريحة). النتيجة: الحدّ الحادّ أصغر بـ 2.4 مرّة. الربط بالذكاء الاصطناعي: استخدم الحدّ الحادّ في الحسابات الدقيقة والمريح في التحليل المقارب.

مثال (3.31-3): مقارنة الصيغتين عند $d = 10, m = 100$ المعطيات: فضاء بُعده 10 ومئة نقطة. المطلوب:

الحدّان. الحل: الخطوة 1: الحدّ المهيمن $\binom{100}{10} = 1.731 \times 10^{13}$؛ والمجموع $\approx 1.94 \times 10^{13}$. الخطوة 2: $(e \cdot 100/10)^{10} = (27.18)^{10} \approx 2.0 \times 10^{14}$. النتيجة: الصيغة المريحة أكبر بنحو عشر مرّات. الربط بالذكاء الاصطناعي: في التحليل المقارب لا يهمّ (عامل ثابت)، وفي الحساب الدقيق يهمّ.

مثال (31.3-4): منطقة التحطيم المعطيات: $d = 4$ و $m = 3$. المطلوب: $\Pi_{\mathcal{H}}(3)$. الحل: الخطوة 1: بما أنّ $m \le d$ فإنّ كلّ الوسوم ممكنة. الخطوة 2: $\Pi = 2^3 = 8$. النتيجة: تطابق تامّ بين الحدّ والقيمة. الربط بالذكاء الاصطناعي: السعة «تُستوفى» في منطقة التحطيم فقط.

مثال (31.3-5): أقصى وسوم لفئة بُعدها 2 على ستّ نقاط المعطيات: $d = 2$، $m = 6$. المطلوب: الحدّ الأعلى. الحل: الخطوة 1: $1 + 6 + 15 = 22$. النتيجة: من 64 وسماً ممكناً لا يتجاوز العدد 22. الربط بالذكاء الاصطناعي: الفجوة بين 64 و 22 هي «ما توفّره السعة المحدودة».

مثال (31.3-6): حساب $\Pi_{\mathcal{H}}(2n)$ لحدّ تعميم المعطيات: $d = 3$، $n = 1000$. المطلوب: $\Pi_{\mathcal{H}}(2000)$. الحل: الخطوة 1: $\binom{2000}{3} = 1.331 \times 10^9$. الخطوة 2: المجموع $\approx 1 + 2000 + 1.999 \times 10^6 + 1.331 \times 10^9 \approx 1.333 \times 10^9$. النتيجة: رقم يُدخل مباشرة في حدّ (31.5) في النظرية القادمة. الربط بالذكاء الاصطناعي: خطوة حسابية تتكرّر في كلّ حدود السعة.

مثال (31.3-7): حالة $d = 1$ المعطيات: فئة بُعدها 1 (كجذوع القرار باتجاه واحد)، $m = 100$. المطلوب: الحدّان. الحل: الخطوة 1: حدّ Sauer: $101 = 100 + 1$. الخطوة 2: الصيغة المريحة: $(e \cdot 100)^1 = 271.8$. النتيجة: الصيغة المريحة فضفاضة بـ 7.2 مرّة عند $d = 1$. الربط بالذكاء الاصطناعي: عند الأبعاد الصغيرة استخدم الحدّ الحادّ دائماً.

مثال (31.3-8): سعة لانهائية $\Rightarrow$ نموّ أسّي دائماً المعطيات: $d_{\mathrm{VC}} = \infty$. المطلوب: $\Pi_{\mathcal{H}}(m)$. الحل: الخطوة 1: لكلّ m توجد مجموعة محطومة $\Rightarrow \Pi_{\mathcal{H}}(m) = 2^m$. النتيجة: لا انحناء ولا كثير حدود $\Rightarrow$ لا حدّ تعميم من هذا النوع. الربط بالذكاء الاصطناعي: هذا هو حال الشبكات العميقة الحديثة (31.8).

مثال (31.3-9): فضاء بُعده 3 على خمس نقاط المعطيات: $d = 3$، $m = 5$. المطلوب: الحدّ. الحل: الخطوة 1: $1 + 5 + 10 + 10 = 26$. النتيجة: 26 من أصل 32 وسماً. الربط بالذكاء الاصطناعي: عند m قريب من d يكون الحدّ شبه كامل.

مثال (31.3-10): أثر مضاعفة m المعطيات: $d = 5$؛ $m = 20$ ثمّ $m = 40$. المطلوب: نموّ الحدّ. الحل: الخطوة 1: $m = 20$: $\sum_{i=0}^{5} \binom{20}{i} = 1 + 20 + 190 + 1140 + 4845 + 15504 = 21700$. الخطوة 2: $m = 40$: $1 + 40 + 780 + 9880 + 91390 + 658008 = 760099$. الخطوة 3: النسبة $760099/21700 \approx 35$. النتيجة: مضاعفة النقاط ضاعفت الحدّ $2^5 = 32 \approx$ مرّة (سلوك m^d). الربط بالذكاء الاصطناعي: تأكيد عددي لكون النموّ كثير حدود بدرجة d.

مثال (31.3-11): فئة بُعدها صفر المعطيات: $\mathcal{H}$ بفرضية واحدة. المطلوب: $\Pi_{\mathcal{H}}(m)$. الحل: الخطوة 1: $d_{\mathrm{VC}} = 0 \Rightarrow \binom{m}{0} = 1 \le \Pi$. النتيجة: وسم واحد فقط على أيّ عدد من النقاط. الربط بالذكاء الاصطناعي: «نموذج ثابت» بلا تعلّم — الحدّ يلتقط ذلك فوراً.

مثال (31.3-12): رتابة دالّة النموّ المعطيات: $\Pi_{\mathcal{H}}(5) = 32$. المطلوب: هل يمكن أن يكون $\Pi_{\mathcal{H}}(6) = 40$؟ الحل: الخطوة 1: دالّة النموّ غير متناقصة، و$\Pi(m) \le \Pi(m+1)$. الخطوة 2: لكن $\Pi(5) = 32 = 2^5$ يعني تحطيم $5 \Rightarrow d \ge 5 \Rightarrow \sum_{i=0}^{d} \binom{6}{i} \ge 42$ والحدّ غير محقَّق بالمساواة. الربط بالذكاء الاصطناعي: مثال على أنّ الحدود «ممكنة» لا «قيم فعلية».

مثال (31.3-13): عند $m = 2d$ المعطيات: $d = 10$، $m = 20$. المطلوب: نسبة الحدّ إلى 2^m. الحل: الخطوة 1: $2^{20} = 1.049 \times 10^6$. الخطوة 2: $\sum_{i=0}^{10} \binom{20}{i} \approx 6.16 \times 10^5$ (المجموع الجزئي الأكبر). الخطوة 3: النسبة ≈ 0.59.

النتيجة: عند $m = 2d$ ما زال الحدّ قريباً من الأسّي. الربط بالذكاء الاصطناعي: «فائدة السعة المحدودة» تظهر فعلاً عند $m \gg d$.

مثال (14-3.31): مضاعفة البيانات في منطقة كثير الحدود المعطيات: $d = 10$، $m = 10^3$ ثمّ $m = 10^4$. المطلوب: نموّ الحدّ. الحل: الخطوة 1: $\binom{10^3}{10} \approx 2.6 \times 10^{23}$ (ومعاملات تصحيح طفيفة). الخطوة 2: $\approx \binom{10^4}{10} \approx 2.7 \times 10^{33}$. الخطوة 3: النسبة $(10)^{10} = 10^{10} \approx$ سلوك m^d بالضبط. النتيجة: تحقّق مباشر لأُسّ m^d. الربط بالذكاء الاصطناعي: كلّما صغر d كانت فائدة البيانات أكبر.

مثال (15-3.31): التقدير التجريبي للسعة المعطيات: نريد معرفة d_{VC} لنموذج صندوق أسود. المطلوب: الطريقة. الحل: الخطوة 1: نولّد m نقطة ونحسب عدد الوسوم الممكنة (بإعادة التدريب على كلّ وسم). الخطوة 2: نجد أكبر m يحقّق $2^m \Rightarrow$ تقدير أدنى لـ d_{VC}. الخطوة 3: التكلفة أسّية $\Rightarrow$ نكتفي بحدود سفلية صغيرة أو نستخدم حدود بديلة. النتيجة: حساب d_{VC} تجريبيّاً مكلف؛ التحليل أفضل. الربط بالذكاء الاصطناعي: سبب شيوع مقاييس السعة البديلة (التغطية، Rademacher، المعايير).

أخطاء شائعة

- استخدام $(em/d)^d$ عند $m < d$ (غير صالح؛ استخدم 2^m).
- الخلط بين $\Pi_{\mathcal{H}}(m)$ (عدد الوسوم) وd_{VC} (أكبر حجم محطوم).
- افتراض أنّ الحدّ محقَّق بالمساواة دائماً (قد يكون فضفاضاً).
- نسيان أنّ دالّة النموّ تأخذ **الأقصى** على ترتيب النقاط لا متوسطه.
- تطبيق Sauer على فئة سعتها لانهائية.

المبرهنة (مبرهنة فابنيك–تشرونِنكِس / «مبرهنة التأسيس»): لتكن $\mathcal{H}$ بِبُعد $d_{\mathrm{VC}} = d < \infty$ والخسارة محصورة. لكلّ $\delta \in (0,1)$، باحتمال $\geq 1-\delta$ على سحب $S \sim \mathcal{D}^n$، **لكلّ** $h \in \mathcal{H}$:

$$R(h) \;\leq\; \hat{R}_S(h) \;+\; \sqrt{\frac{8}{n}\,\ln\frac{4\,\Pi_{\mathcal{H}}(2n)}{\delta}} \tag{5.31}$$

وبمتراجحة Sauer يكفي

$$R(h) \;\leq\; \hat{R}_S(h) \;+\; \sqrt{\frac{8}{n}\left(d\,\ln\frac{2en}{d} \;+\; \ln\frac{4}{\delta}\right)} \tag{6.31}$$

وينتج عنها **تعقيد العيّنة**: لتحقيق فجوة ε يكفي

$$n \;=\; O\!\left(\frac{d + \ln(1/\delta)}{\varepsilon^2}\right) \tag{7.31}$$

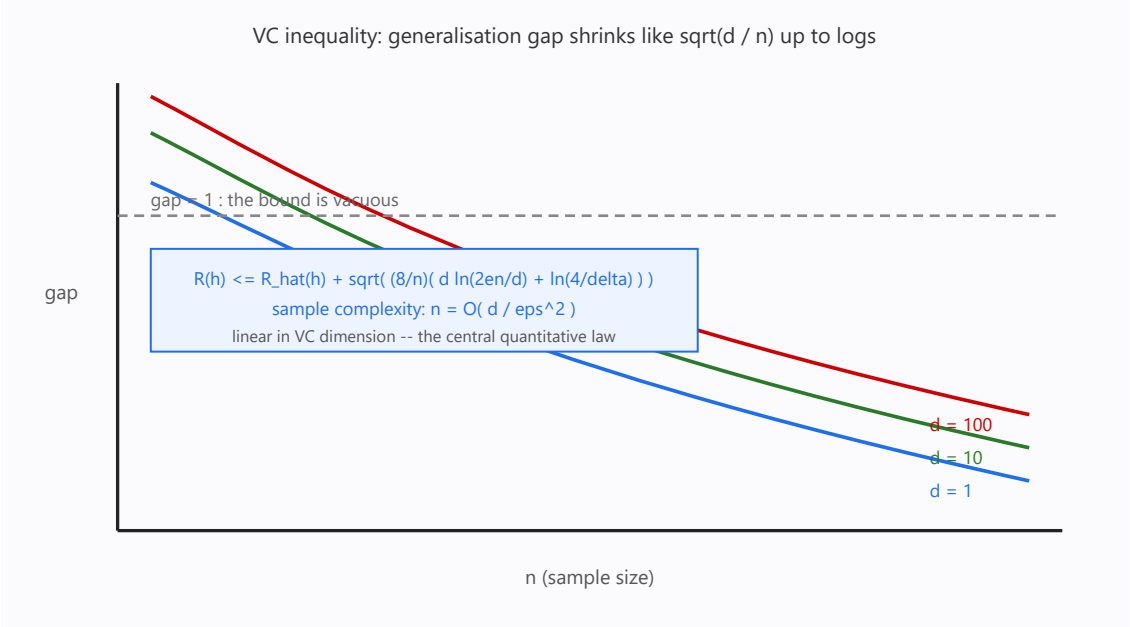
أي أنّ عدد العيّنات المطلوب **خطّي** في بُعد VC وتربيعي في مقلوب الدقّة.

جدول الرموز

الرمز	المعنى	ملاحظة
$\Pi_{\mathcal{H}}(2n)$	دالّة النموّ عند $2n$	تظهر $2n$ لا تقنياً n
$\frac{8}{n}$	ثابت الحدّ	يختلف بين المراجع
$d \ln \frac{2en}{d}$	أثر السعة	لوغاريتمي مضروب بـ d
$\ln(4/\delta)$	أثر الثقة	لوغاريتمي
$n \propto d/\varepsilon^2$	قانون تعقيد العيّنة	النتيجة العملية الكبرى
لا يعتمد على الخوارزمية	الحدّ لكلّ $h \in \mathcal{H}$	سيرثه ERM وغيره

الرسم

<figure> الشكل<figcaption> 4.31: فجوة التعميم المضمونة تهبط كـ $\sqrt{d/n}$ (مع لوغاريتمات)؛ ومضاعفة السعة



شكل ٤.٣١: *
متراجحة VC وتعقيد العينة

أسهل من مضاعفة الدقّة.</figcaption> </figure>

البرهان (مخطّط)

الخطوة 1 (اختزال إلى فضاء منتهٍ): بدل المقارنة بين $R(h)$ و $\hat{R}(h)$ على العيّنة نفسها، نستخدم «عيّنة وهمية» S' ثانية: يتحوّل الأمر إلى مقارنة $\hat{R}_{S'}(h)$ بـ $\hat{R}_S(h)$ على $2n$ نقطة، وهذا يقع في فضاء منته عددُ عناصره الفعّالة $\Pi_{\mathcal{H}}(2n)$.

الخطوة 2 (اتّحاد + هوفدينغ مزدوج): بتطبيق متراجحة هوفدينغ على الفرق $\hat{R}_{S'} - \hat{R}_S$ (متغيّرات مستقلّة) ثمّ اتّحاد على $\Pi_{\mathcal{H}}(2n)$ عنصر، نحصل على حدّ من الشكل $\sqrt{\frac{8}{n} \ln \frac{4\Pi(2n)}{\delta}}$ بعد معالجة ثابت «التماثل» (symmetrization) بحيلة استبدال المتغيّرات.

الخطوة 3 (الانتقال إلى الخطر الحقيقي): بربط $\mathbb{E}[\hat{R}_{S'}]$ بـ R والتحكّم في الفرق بين «الخطر» و«متوقّع الخطر التجريبي المزدوج» بحدّ إضافي من الرتبة نفسها $\Rightarrow$ (5.31). ■

الخطوة 4 (Sauer): تعويض (4.31) في (5.31) يعطي (6.31). ■

الخطوة 5 (تعقيد العيّنة): بحلّ (6.31) لـ n: نطلب $\varepsilon^2 \le \frac{8}{n}\big(d\ln\frac{2en}{d} + \ln\frac{4}{\delta}\big)$؛ ولأنّ اللوغاريتم داخل n، يُحلّ تكراريّاً فيعطي المقياس $n = \Theta\big(\frac{d+\ln(1/\delta)}{\varepsilon^2}\big)$ مع ثوابت ولوغاريتمات إضافية. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.31): حدّ لفضاء بُعده 3 المعطيات: $d=3$، $n=1000$، $\delta=0.05$. المطلوب: هامش التعميم بالصيغتين. الحل: الخطوة 1: $\Pi_{\mathcal{H}}(2000) \approx 1.333\times10^{9} \Rightarrow \ln(4\Pi/\delta) = \ln(1.067\times10^{11}) = 25.393$. الخطوة 2: بالصيغة (5.31): $\sqrt{\frac{8}{1000}(25.393)} = \sqrt{0.2031} = 0.4507$. الخطوة 3: بالصيغة (6.31): $d\ln(2en/d) = 3\ln(1812.2) = 22.506$؛ $+\ln 80 = 4.382 \Rightarrow 26.888 \Rightarrow \sqrt{0.2151} = 0.4638$.
النتيجة: نحو 45 نقطة مئوية هامش — صحيح لكن فضفاض جدّاً. الربط بالذكاء الاصطناعي: هذه «فضفاضية» حدود VC معروفة: قيمتها في **الاتجاه** لا في الرقم.

مثال (2-4.31): أثر مضاعفة العيّنة مئة ضعف المعطيات: $d=3$، $n=10^5$، $\delta=0.05$. المطلوب: الهامش. الحل: الخطوة 1: $2en/d = 1.812\times10^{5}$؛ $\ln = 12.108$؛ $\times 3 = 36.324$؛ $+\ln 80 = 4.382 \Rightarrow 40.706$. الخطوة 2: $\sqrt{\frac{8}{10^5}(40.706)} = \sqrt{0.003256} = 0.0571$. النتيجة: من 0.464 إلى 0.057 — تحسّن بمعامل 8 (ليس 10 بسبب اللوغاريتم). الربط بالذكاء الاصطناعي: معدّل قريب من $1/\sqrt{n}$ كما في الفصل 30.

مثال (3-4.31): بُعد أكبر بعشر مرّات المعطيات: $d=100$، $n=10^4$، $\delta=0.05$. المطلوب: الهامش. الحل: الخطوة 1: $2en/d = 543.6 \Rightarrow \ln = 6.298 \Rightarrow \times 100 = 629.8$؛ $+4.382 = 634.2$. الخطوة 2: $\sqrt{\frac{8}{10^4}(634.2)} = \sqrt{0.5074} = 0.7123$. النتيجة: الهامش 71% — حدّ شبه فارغ رغم عشرة آلاف عيّنة. الربط بالذكاء الاصطناعي: الأبعاد العالية مكلفة نظريّاً، وهذا أحد دوافع تعلّم التمثيل.

مثال (4-4.31): تعقيد العيّنة لفجوة 5% المعطيات: $d=10$؛ نريد $\varepsilon=0.05$، $\delta=0.05$. المطلوب: n بالقانون وبالحدّ الصريح. الحل: الخطوة 1: القانون (7.31): $n \approx \frac{10+3}{0.0025} = 5200$. الخطوة 2: بالحدّ الصريح نشترط $3.125\times10^{-4}n = \frac{0.0025}{8}n \le 10\ln(0.2718n) + 4.382$. الخطوة 3: عند $n = 8\times10^{5}$: طرف أيسر $10\ln(217440) + 4.382 = 127.3$، وأيمن $250 \Rightarrow$ يتحقّق. الخطوة 4: عند $n = 4\times10^{5}$: أيسر 126.6، وأيمن $125 \Rightarrow$ لا يتحقّق. النتيجة: الحدّ الصريح يحتاج $4\times10^{5} \approx$ عيّنة أي نحو 80 ضعف ما يوحي به القانون. الربط بالذكاء الاصطناعي: الفرق بين «المقياس المقارب» و«الحدّ القابل للحساب» فرق عملي كبير.

مثال (5-4.31): أثر مضاعفة الدقّة المعطيات: $d=10$؛ من $\varepsilon=0.1$ إلى $\varepsilon=0.05$. المطلوب: أثر ذلك على n. الحل: الخطوة 1: بالقانون $n \propto 1/\varepsilon^2 \Rightarrow$ مضاعفة الدقّة تكلّف 4 أضعاف البيانات. الخطوة 2: من $\varepsilon=0.2$ إلى 0.02 (عشر مرّات) $\Rightarrow$ 100 ضعف البيانات. النتيجة: الدقّة أغلى من السعة بكثير. الربط بالذكاء الاصطناعي: قاعدة تخطيط الميزانية: حدّد الدقّة المطلوبة أوّلاً.

مثال (6-4.31): تكلفة الثقة المعطيات: $d=10$، $n=10^5$، δ من 0.05 إلى 0.005. المطلوب: تغيّر الهامش. الحل: الخطوة 1: $\delta=0.05$: $\ln(4/0.05) = 4.382$؛ $\delta=0.005$: $\ln(800) = 6.685$. الخطوة 2: بقية المقدار $10\ln(54366) = 109.03$ $\Rightarrow$ المجموعان 113.41 و 115.72. الخطوة 3: النسبة $\sqrt{115.72/113.41} = 1.010$. النتيجة: زيادة الثقة عشر مرّات كلّفت 1% فقط في الهامش. الربط بالذكاء الاصطناعي: في حدود السعة، الثقة رخيصة والبيانات غالية.

مثال (7-4.31): مضاعفة السعة المعطيات: d من 10 إلى 20 عند $n=10^5$. المطلوب: أثر ذلك. الحل: الخطوة 1: $d=10$: $10\ln(54366) + 4.38 = 113.41$؛ $d=20$: $20\ln(27183) + 4.38 = 208.61$. الخطوة 2: النسبة في الهامش $\sqrt{208.61/113.41} = 1.356$. النتيجة: مضاعفة السعة $\Rightarrow$ +37% في الهامش فقط. الربط بالذكاء الاصطناعي: مضاعفة السعة أرخص من مضاعفة الدقّة (التي تكلف 4 أضعاف).

مثال (8-4.31): عشرات أضعاف البيانات المعطيات: $d=50$، $n=10^4$ ثمّ $n=10^5$ ثمّ $n=10^6$. المطلوب:

مسار الهامش. الحل: الخطوة 1: $n = 10^4 : 348.9 = 50\ln(1087.2) \Rightarrow 0.5317 = \sqrt{8(353.3)/10^4}$. الخطوة 2: $n = 10^5 : 464.7 = 50\ln(10872) \Rightarrow 0.1938 = \sqrt{8(469.1)/10^5}$. الخطوة 3: $n = 10^6 : 580.5 = 50\ln(108720) \Rightarrow 0.0684 = \sqrt{8(584.9)/10^6}$. النتيجة: $0.532 \to 0.194 \to 0.068$ — معدّل يقارب $1/\sqrt{n}$ مع تباطؤ لوغاريتمي. الربط بالذكاء الاصطناعي: هذا هو الشكل النظري لمنحنى التعلّم من الفصل 30.

مثال (9-4.31): اختيار نموذج بعقوبة SRM VC) بُعد (VC المعطيات: ثلاث فئات بـ $d = 5, 50, 500$ وأخطاء تدريب $0.20, 0.12, 0.02$، $n = 10^4$، $\delta = 0.05$. المطلوب: أيّ فئة نختار؟ الحل: الخطوة 1: العقوبات: $d = 5 : \sqrt{8(50.5)/10^4} = \sqrt{8(5\ln(10872) + 4.38)/10^4} = 0.201$. الخطوة 2: $d = 50 :$ 0.532؛ $d = 500 : 2344 = 50\ln(108.7) \Rightarrow 1.371 = \sqrt{8(2348)/10^4}$ (فارغ). الخطوة 3: الحدود: $0.401,\ 0.652,\ 1.391$. النتيجة: نختار الفئة الأصغر ($d = 5$) بحدّ 0.401. الربط بالذكاء الاصطناعي: تطبيق مباشر لـ SRM من الفصل 30 بعقوبة محسوبة لا مفترضة.

مثال (10-4.31): سعة أشجار القرار المعطيات: شجرة محورية بـ $m = 16$ ورقة في $\mathbb{R}^{10}$. المطلوب: بُعد VC التقريبي. الحل: الخطوة 1: بُعد VC لأشجار محورية بـ m ورقة في $\mathbb{R}^d$ هو $\Theta(m \log d)$. الخطوة 2: $16\log_2(10) = 16(3.322) = 53.2$. النتيجة: نحو 53 — رقم يمكن إدخاله في (6.31) مباشرة. الربط بالذكاء الاصطناعي: يبرّر تقليم الأشجار: كلّ ورقة تُحذف تقلّل السعة خطّياً.

مثال (11-4.31): كثيرات الحدود من درجة p المعطيات: مصنّفات كثيرة حدود من درجة 3 في $\mathbb{R}^2$. المطلوب: d_{VC}. الحل: الخطوة 1: عدد الحدود $= \binom{5}{3} = \binom{d+p}{p}$. الخطوة 2: بُعد VC يساوي عدد المعلمات هنا $\Rightarrow d_{\text{VC}} = 10$. النتيجة: درجة 3 في بعد 2 $\Rightarrow$ سعة 10 فقط. الربط بالذكاء الاصطناعي: لهذا تُستخدم «حيل النواة»: درجات عالية بسعة محسوبة.

مثال (12-4.31): سعة تجميعة مُعزَّزة المعطيات: تصويت أغلبي على $T = 100$ جذعاً في بعد واحد ($d_{\text{stump}} = 2$). المطلوب: حدّ السعة. الحل: الخطوة 1: بُعد VC لتصويت أغلبي على T مصنّفات بُعد كلّ منها d هو $O(Td\log(Td))$. الخطوة 2: $100 \times 2 \times \ln(200) = 1059 \Rightarrow$ نحو 10^3. النتيجة: التعزيز يضخّم السعة خطّياً في T مع لوغاريتم. الربط بالذكاء الاصطناعي: يفسّر الحاجة للتحكّم في عدد جولات التعزيز رغم نجاحه العملي.

مثال (13-4.31): آلة نووية بسعة لانهائية المعطيات: SVM بنواة غاوسية، $n = 10^4$. المطلوب: هل ينفع حدّ (6.31)؟ الحل: الخطوة 1: $d_{\text{VC}} = \infty \Rightarrow$ الحدّ غير معرّف (فارغ). الخطوة 2: ومع ذلك SVM يعمل $\Rightarrow$ نحتاج حدود الهامش (7.31). النتيجة: حدود السعة الخام تعجز عن تفسير أنجح الطرق الكلاسيكية. الربط بالذكاء الاصطناعي: الدافع التاريخي المباشر لنظرية الهامش.

مثال (14-4.31): لماذا تعجز الحدود عن الشبكات العميقة؟ المعطيات: شبكة بـ $W = 10^7$ و $L = 16$، $n = 5 \times 10^4$. المطلوب: قيمة (6.31). الحل: الخطوة 1: $d_{\text{VC}} \approx WL\log W \approx 1.6 \times 10^8 \times 16.1 \approx 2.6 \times 10^9$. الخطوة 2: بما أنّ $d = 10^5 < 2n$ $\Rightarrow \Pi_{\mathcal{H}}(2n) = 2^{10^5} \Rightarrow \ln \frac{4\Pi}{\delta} \approx 69319$. الخطوة 3: $\sqrt{\frac{8}{5\times10^4}(69319)} = \sqrt{11.09} = 3.33 > 1$. النتيجة: الحدّ فارغ تماماً (أكبر من أقصى خطر ممكن). الربط بالذكاء الاصطناعي: هذه النتيجة بالتحديد هي التي فتحت باب الفصل 34.

مثال (15-4.31): تخطيط عيّنة لتصوير طبي المعطيات: نموذج بـ $d = 20$؛ نريد $\varepsilon \le 0.02$، $\delta = 0.05$. المطلوب: حجم العيّنة. الحل: الخطوة 1: الشرط من (6.31) هو $\frac{8}{n}\big(20\ln(0.2718\,n) + 4.382\big) \le (0.02)^2 = 4\times10^{-4}$. الخطوة 2: عند $n = 10^7$: الطرف الأيسر $= \frac{8}{10^7}\big(20(14.815)+4.38\big) = 2.374\times10^{-4} \le 4\times10^{-4}$ ✓. الخطوة 3: عند $n = 5\times10^6$: $= \frac{8}{5\times10^6}\big(20(14.122)+4.38\big) = 4.53\times10^{-4} > 4\times10^{-4}$ ×. النتيجة: نحو 7×10^6 عيّنة — رقم غير واقعي طبيّاً. الربط بالذكاء الاصطناعي: دليل قاطع على أنّ الحدود «موجّهة»؛ الممارسة تعتمد على التجربة والتحقق (الفصول 33–34).

أخطاء شائعة

- إسقاط عامل $2n$ واستخدام $\Pi_{\mathcal{H}}(n)$ (خطأ شائع في الحدود).
- نسيان أنّ الحدود فضفاضة: استخدامها لتقدير «الدقّة المتوقعة» لا «الضمان الأقصى».
- تطبيقها على فئات سعتها لانهائية (نواة، شبكات) بلا هامش أو تنظيم.
- الخلط بين تعقيد العيّنة المقارب (7.31) والحدّ الصريح (6.31).
- افتراض أنّ السعة وحدها تحدّد التعميم (الخوارزمية والتوزيع يحدّدانه أيضاً — الفصل 33).

المبرهنة: ليكن $\mathcal{F}$ فضاء دوالّ حقيقية على $\mathcal{Z}$ و $S = \{z_1, \dots, z_n\}$ عيّنةً، و $\sigma_1, \dots, \sigma_n$ إشارات رادِماخر مستقلّة (± 1 باحتمال $\frac{1}{2}$). عرّف

$$\hat{\mathfrak{R}}_S(\mathcal{F}) \;=\; \mathbb{E}_{\sigma}\left[\sup_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^{n} \sigma_i f(z_i) \right] \tag{8.31}$$

فباحتمال $\geq 1 - \delta$، لكلّ $f \in \mathcal{F}$:

$$R(f) \;\leq\; \hat{R}_S(f) \;+\; 2\,\hat{\mathfrak{R}}_S(\mathcal{F}) \;+\; 3\sqrt{\frac{\ln(2/\delta)}{2n}} \tag{9.31}$$

ولفضاء منتهٍ (متراجحة ماسّار):

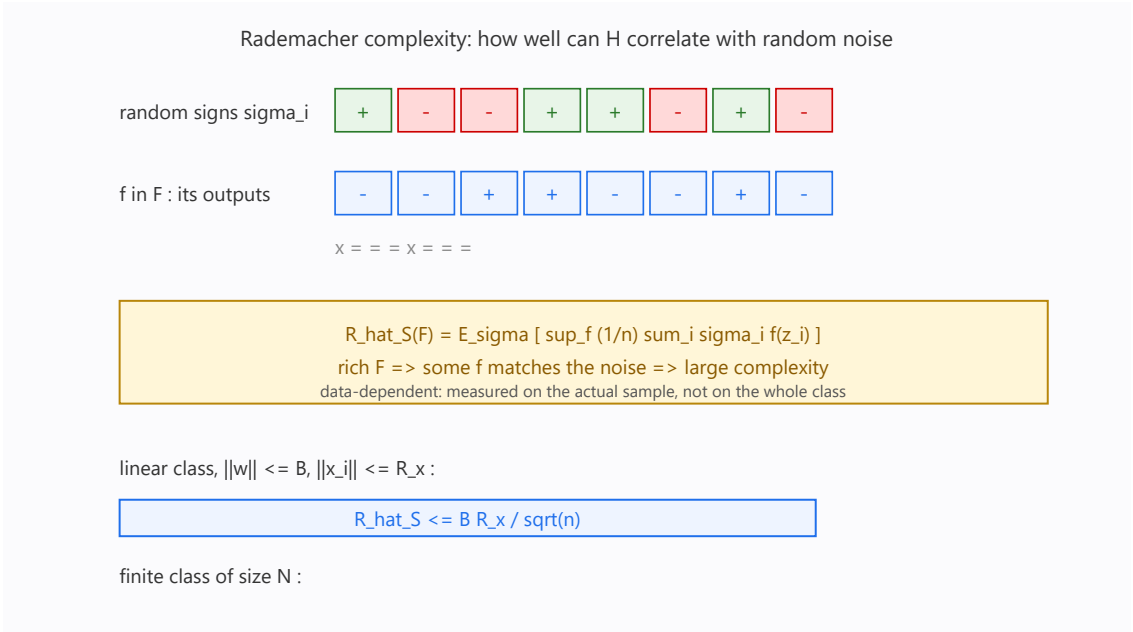
$$\hat{\mathfrak{R}}_S(\mathcal{F}) \;\leq\; \sqrt{\frac{2 \ln |\mathcal{F}|}{n}} \tag{10.31}$$

وللصنف الخطّي المقيّد بـ $\|w\|_2 \leq B$:

$$\hat{\mathfrak{R}}_S\big(\{x \mapsto w^{\top} x : \; \|w\|_2 \leq B\}\big) \;\leq\; \frac{B}{n} \sqrt{\sum_{i=1}^{n} \|x_i\|_2^2} \;\leq\; \frac{B\, R_x}{\sqrt{n}}, \qquad R_x = \max_i \|x_i\|_2 \tag{11.31}$$

جدول الرموز

الرمز	المعنى	ملاحظة
σ_i	إشارات عشوائية ± 1	«ضجيج نصفه موجب»
$\sup_f$	أفضل فرضية تطابق الضجيج	جوهر القياس
$\hat{\mathfrak{R}}_S$	تعقيد تجريبي	يُحسب من العيّنة
$\mathfrak{R}_n$	التعقيد المتوقّع $\mathbb{E}_S[\hat{\mathfrak{R}}_S]$	يعتمد على $\mathcal{D}$
ماسّار	حدّ للفضاءات المنتهية	$\sqrt{2 \ln \|\mathcal{F}\| / n}$
يعتمد على البيانات	ميزته الكبرى	يقيس ما تملكه فعلاً



شكل ٥.٣١: *
تعقيد Rademacher

الرسم

<figure> الشكل<figcaption> 5.31: التعقيد يقيس قدرة الفضاء على «ملاءمة الضجيج العشوائي»: كلّما استطاع بعضُ f مطابقة الإشارات، كبر التعقيد.</figcaption> </figure>

البرهان (مخطّط)

الخطوة 1 (التماثل :(Symmetrization) نريد التحكّم في $\sup_f (R(f) - \hat{R}(f))$؛ بإدخال عيّنة وهمية S' وتوقعاتها، تُختزل المسألة إلى التحكّم في

$$\sup_f \frac{1}{n}\sum_i \big(f(z_i') - f(z_i)\big)$$

الذي — بتوزيع متماثل — يكافئ في التوقّع $\sup_f \frac{1}{n}\sum_i \sigma_i f(z_i)$.

الخطوة 2 (تركيز للقيمة المتوقّعة): تُطبَّق متراجحة ماكْديارميد (McDiarmid) على $\hat{\mathfrak{R}}_S$ بوصفه دالّةً في S (تغيّر نقطة واحدة يغيّره بمقدار $\le 2/n$) $\Rightarrow$ حدّ التركيز $3\sqrt{\ln(2/\delta)/(2n)}$ في (9.31). ■

الخطوة 3 (ماسّار): لفضاء منته، بالاتّحاد على $|\mathcal{F}|$ واستخدام تركيز المتّجهات العشوائية: $\hat{\mathfrak{R}}_S \le \frac{\max_f \|f\|_2}{n}\sqrt{2\ln|\mathcal{F}|} \le \sqrt{2\ln|\mathcal{F}|/n}$ للقيم المقيّدة. ■

الخطوة 4 (الخطّي): $\sup_{\|w\|\le B} \frac{1}{n}\sum_i \sigma_i w^\top x_i = \frac{B}{n}\|\sum_i \sigma_i x_i\|_2$؛ وبجنسن/كاوشي–شوارتز $\Rightarrow \mathbb{E}\|\sum \sigma_i x_i\| \le \sqrt{\sum \|x_i\|^2}$ (11.31). ■

خمسة عشر مثالاً محلولاً

مثال (1-5.31): قراءة التعريف المعطيات: عيّنة من 100 نقطة وفضاء فرضيات. المطلوب: ماذا يعني $\hat{\mathfrak{R}}_S = 0.25$؟
الحل: الخطوة 1: نرمي إشارات عشوائية ونبحث عن أفضل f يطابقها. الخطوة 2: متوسط التطابق 0.25 من أقصى ممكن

(=1). النتيجة: ربع «الضجيج» قابل للملاءمة ⇒ فجوة تعميم $0.5 \approx$ بالحدّ (9.31). الربط بالذكاء الاصطناعي: تفسير مباشر لظاهرة «حفظ الوسوم العشوائية».

مثال (5.31-2): صنف خطّي مقيّد المعطيات: $B = 1$، $\|x_i\|_2 = 1$ لكلّ i، $n = 100$. المطلوب: $\hat{\mathfrak{R}}_S$. الحل: الخطوة 1: $\sum_i \|x_i\|^2 = 100 \Rightarrow$ الجذر $= 10$. الخطوة 2: $\frac{B}{n}(10) = \frac{10}{100} = 0.1$ (ويطابق $BR_x/\sqrt{n} = 1/10$). النتيجة: تعقيد 0.1. الربط بالذكاء الاصطناعي: قيد المعيار يترجم مباشرة إلى سعة أصغر — التنظيم again.

مثال (5.31-3): حدّ التعميم الكامل المعطيات: الصنف السابق، $\hat{R}_S = 0.05$، $n = 100$، $\delta = 0.05$. المطلوب: حدّ (9.31). الحل: الخطوة 1: $2\hat{\mathfrak{R}}_S = 0.2$. الخطوة 2: $3(0.13581) = 3\sqrt{0.018445} = 3\sqrt{\ln 40/200} = 0.4074$. الخطوة 3: المجموع $0.6574 = 0.4074 + 0.2 + 0.05 =$. النتيجة: حدّ ضخم — لأنّ $n = 100$ صغير جدّاً. الربط بالذكاء الاصطناعي: قاعدة: الحدود المفيدة تبدأ عند آلاف العيّنات لا مئاتها.

مثال (5.31-4): تحسين الحدّ بمئة ضعف البيانات المعطيات: نفس الصنف، $n = 10^4$، $\hat{R}_S = 0.05$، $B = 1$، $R_x = 1$. المطلوب: الحدّ. الحل: الخطوة 1: $\hat{\mathfrak{R}}_S = 1/100 = 0.01 \Rightarrow 2\hat{\mathfrak{R}} = 0.02$. الخطوة 2: $3(0.013581) = 3\sqrt{3.689/20000} = 0.0407$. الخطوة 3: المجموع $0.1107 = 0.05 + 0.02 + 0.0407 =$. النتيجة: من 0.657 إلى 0.111. الربط بالذكاء الاصطناعي: معدّل التحسّن يقارب $1/\sqrt{n}$ لكلا الحدّين.

مثال (5.31-5): ماسّار مقابل حدّ الفضاء المنتهي المعطيات: $|\mathcal{F}| = 10^6$، $n = 1000$. المطلوب: مقارنة (10.31) مع (6.30) من الفصل 30. الحل: الخطوة 1: ماسّار: $\sqrt{2(13.816)/1000} = \sqrt{2\ln(10^6)/1000} = 0.1662$. الخطوة 2: في (9.31) يضرب بـ 2 $\Rightarrow 0.3324$ زائد التركيز $0.1358 \Rightarrow 0.468$. الخطوة 3: حدّ الفصل 30: $\sqrt{\ln(4 \times 10^6/0.05)/2000} = \sqrt{18.197/2000} = 0.0954$. النتيجة: حدّ الفصل 30 أوثق هنا (0.095 مقابل 0.468). الربط بالذكاء الاصطناعي: لا «أفضل حدّ» مطلق؛ كلّ حدّ له موضع قوّة.

مثال (5.31-6): أقصى تعقيد = ملاءمة الوسوم العشوائية المعطيات: $\mathcal{F}$ قادر على تحقيق أيّ وسم (سعة لانهائية)، خسارة في $[0,1]$. المطلوب: $\hat{\mathfrak{R}}_S$. الحل: الخطوة 1: نختار f لتطابق كلّ الإشارات $\Rightarrow \frac{1}{n}\sum \sigma_i f(z_i) = \frac{1}{2}$ تقريباً. النتيجة: $\hat{\mathfrak{R}}_S \to \frac{1}{2} \Rightarrow$ الحدّ (9.31) يعطي فجوة ≥ 1 (فارغ). الربط بالذكاء الاصطناعي: هذا بالضبط قياس (Zhang) وآخرون على الشبكات العميقة.

مثال (5.31-7): اعتماد التعقيد على البيانات المعطيات: صنف خطّي بـ $B = 1$، بيانات على كرة نصف قطرها 1 مقابل بيانات مركّزة في اتجاه واحد. المطلوب: الفرق في التعقيد. الحل: الخطوة 1: الحالة الأولى: $\sqrt{\sum \|x_i\|^2/n} = 1/\sqrt{n}$. الخطوة 2: الحالة الثانية (ركيزة منخفضة): $\|\sum \sigma_i x_i\|$ أصغر بكثير $\Rightarrow$ تعقيد أقلّ. النتيجة: نفس $\mathcal{H}$ ونفس B، تعقيد مختلف بحسب هندسة البيانات. الربط بالذكاء الاصطناعي: ميزة حاسمة لحدود Rademacher على حدود VC: تستفيد من البيانات فعلاً.

مثال (5.31-8): أثر التنظيم على التعقيد المعطيات: $n = 1000$، $R_x = 1$، انحدار بـ $\|w\| \leq B$ حيث $B = 1$ مقابل $B = 0.1$. المطلوب: التعقيد في الحالتين. الحل: الخطوة 1: $B = 1$: $\hat{\mathfrak{R}}_S = 1/\sqrt{1000} = 0.0316$. الخطوة 2: $B = 0.1$: $0.00316 =$. النتيجة: تشديد التنظيم عشر مرّات قلّص التعقيد عشر مرّات. الربط بالذكاء الاصطناعي: الوجه الكمّي لقولنا «التنظيم يقلّل السعة» (الفصل 30).

مثال (5.31-9): تعقيد الغلاف المحدّب المعطيات: تصويتٌ مُعزَّز على T مصنّفات من $\mathcal{F}$. المطلوب: هل يكبر التعقيد مع T؟ الحل: الخطوة 1: خصيصة أساسية: $\hat{\mathfrak{R}}_S(\operatorname{conv}\mathcal{F}) = \hat{\mathfrak{R}}_S(\mathcal{F})$. الخطوة 2: التوليفات الخطّية المحدّبة لا تزيد قدرة الفضاء على ملاءمة الضجيج. النتيجة: التعقيد لا ينمو مع عدد الجولات T (بخلاف حدود VC التي تنمو بـ $T \log T$). الربط بالذكاء الاصطناعي: تفسير نظري لنجاح التعزيز رغم نموّ عدد المصنّفات.

مثال (5.31-10): الانكماش اللبشيتزي المعطيات: خسارة الهامش ϕ لبشيتزية بثابت $1/\gamma$ مطبَّقة على $\mathcal{F}$. المطلوب: تعقيد المركّب. الحل: الخطوة 1: متراجحة الانكماش (Talagrand): $\hat{\mathfrak{R}}_S(\phi \circ \mathcal{F}) \leq \frac{1}{\gamma}\hat{\mathfrak{R}}_S(\mathcal{F})$. النتيجة: أداة رئيسية

لاشتقاق حدود الهامش (7.31). الربط بالذكاء الاصطناعي: كلّ حدود الهامش الحديثة مبنيّة على هذه الخصيصة.

مثال (11-5.31): حساب يدوي لفضاء من فرضيتين المعطيات: $n = 4$، $\mathcal{F} = \{f_1, f_2\}$ بقيم $f_1 = (1,0,1,0)$ و $f_2 = (0,1,0,1)$. المطلوب: $\hat{\mathfrak{R}}_S$. الحل: الخطوة 1: $\frac{\sigma_1+\sigma_3}{4}$ = f_1؛ ولـ f_2: $\frac{\sigma_2+\sigma_4}{4}$. الخطوة 2: نأخذ الأفضل: $\frac{1}{4}\max(\sigma_1+\sigma_3,\ \sigma_2+\sigma_4)$. الخطوة 3: بالتوقّع على الإشارات الستّ عشرة: $\hat{\mathfrak{R}}_S = 0.1875 \Rightarrow \mathbb{E}[\max] = 0.75$. النتيجة: رقم يمكن التحقّق منه بالعدّ المباشر. الربط بالذكاء الاصطناعي: تمرين ممتاز لفهم «مطابقة الضجيج» حسابيّاً.

مثال (12-5.31): التعقيد التجريبي مقابل المتوقّع المعطيات: $\hat{\mathfrak{R}}_S$ محسوب على عيّنة واحدة. المطلوب: العلاقة بـ $\mathfrak{R}_n$. الحل: الخطوة 1: $\mathfrak{R}_n = \mathbb{E}_S[\hat{\mathfrak{R}}_S]$. الخطوة 2: بتركيز ماكْديارميد يقترب $\hat{\mathfrak{R}}_S$ من $\mathfrak{R}_n$ بمعدّل $1/\sqrt{n}$. النتيجة: يمكن استخدام التجريبي في الحدود مباشرة (كما في 9.31). الربط بالذكاء الاصطناعي: يجعل الحدود قابلة للحساب الفعلي لا النظري فقط.

مثال (13-5.31): حساب التعقيد عدديّاً المعطيات: فضاء غير منته (شبكة صغيرة). المطلوب: طريقة التقدير. الحل: الخطوة 1: نولّد K متّجهات إشارات $\sigma^{(k)}$. الخطوة 2: لكلّ منها نحوّل $\sup_f \frac{1}{n}\sum \sigma_i f(z_i)$ بتدريبٍ داخلي (أو بتقريب). الخطوة 3: نوسّط على K. النتيجة: تقدير مونتي-كارلو للتعقيد. الربط بالذكاء الاصطناعي: مستخدم فعلاً في أبحاث حدود التعميم التجريبية.

مثال (14-5.31): تعقيد الشبكات بالمعايير المعطيات: شبكة ReLU بـ L طبقات ومعايير طيفية $\|W_l\|_\sigma$. المطلوب: صيغة التعقيد. الحل: الخطوة 1: $\hat{\mathfrak{R}}_S \lesssim \frac{\|X\|_F \prod_l \|W_l\|_\sigma \, L^{3/2}}{\sqrt{n}}$ (صيغة مبسّطة من حدود بارتليت). النتيجة: التعقيد يُضبط بجداء المعايير الطيفية لا بعدد الأوزان وحده. الربط بالذكاء الاصطناعي: يبرّر التطبيع الطيفي بوصفه أداة نظرية لا حيلة عددية.

مثال (15-5.31): لماذا نفضّل Rademacher على VC؟ المعطيات: مهمة رؤية ببيانات مركّزة على متعدّد منخفض البعد. المطلوب: أيّ حدّ نستخدم؟ الحل: الخطوة 1: حدّ VC يعطي رقم واحد لكلّ $\mathcal{H}$ مهما كانت البيانات. الخطوة 2: حدّ Rademacher يصغر حين تكون البيانات «سهلة/مركّزة». النتيجة: الثاني أقرب للواقع، لكنّه أصعب حساباً. الربط بالذكاء الاصطناعي: هذا هو الدافع لكلّ «الحدود المعتمدة على البيانات» الحديثة.

أخطاء شائعة

- نسيان معامل 2 أمام $\hat{\mathfrak{R}}_S$ في (9.31).
- استخدام التعقيد التجريبي لتبرير اختيار النموذج على نفس العيّنة.
- الخلط بين $\hat{\mathfrak{R}}_S$ (إشارات ± 1) وبين تباين الخسارة.
- افتراض أنّ تعقيداً أصغر يعني دائماً خطأً أصغر (هو يعني **فجوة** أصغر).
- حساب $\sup_f$ تقريبيّاً ثمّ معاملة النتيجة كحدّ أعلاه مضمون.

المبرهنة: ليكن $(\mathcal{F}, \|\cdot\|)$ فضاءً متريّاً. عرّف

$$\mathcal{N}(\varepsilon, \mathcal{F}, \|\cdot\|) = \min\left\{N : \exists f_1, \dots, f_N,\ \forall f \in \mathcal{F}\ \exists j :\ \|f - f_j\| \le \varepsilon\right\} \tag{12.31}$$

ولكرة الوحدة في $\mathbb{R}^d$:

$$\mathcal{N}(\varepsilon, B_2^d, \|\cdot\|_2) \;\le\; \left(\frac{3}{\varepsilon}\right)^{d}, \qquad \ln \mathcal{N} = d \ln \frac{3}{\varepsilon} \tag{13.31}$$

وتربط متراجحة Dudley بين التغطية والتعقيد:

$$\hat{\mathfrak{R}}_S(\mathcal{F}) \;\le\; \inf_{\alpha \ge 0} \left\{ 4\alpha \;+\; \frac{12}{\sqrt{n}} \int_{\alpha}^{\hat{D}} \sqrt{\ln \mathcal{N}\big(\varepsilon, \mathcal{F}, L_2(S)\big)}\; d\varepsilon \right\} \tag{14.31}$$

وبالمعايرة للصنف ذي البعد الفعّال d:

$$\hat{\mathfrak{R}}_S(\mathcal{F}) \;\approx\; \frac{12}{\sqrt{n}} \cdot 1.43 \sqrt{d} \;=\; 17.2 \sqrt{\frac{d}{n}} \tag{15.31}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$\mathcal{N}(\varepsilon)$	رقم التغطية	عدد الكرات المطلوبة
$\ln \mathcal{N}$	الإنتروبيا المترية	«عدد البتّات» لوصف الفضاء
$L_2(S)$	المعيار التجريبي $\sqrt{\frac{1}{n}\sum f(z_i)^2}$	يعتمد على العيّنة
$1/\varepsilon$	دقّة التقريب	كلّما صغر كبر الرقم
d في الأُسّ	البعد الفعّال	من (13.31)
$\hat{D}$	قطر الفضاء	حدّ التكامل الأعلى

الرسم

<figure> الشكل<figcaption> 6.31: عدد الكرات اللازمة لتغطية الفضاء بدقّة ε هو مقياس هندسي للسعة، ولوغاريتمه هو «الإنتروبيا المترية».</figcaption> </figure>

البرهان (مخطّط)

الخطوة 1 (كرة الوحدة): بحجّة حجمية (volumetric): كرة نصف قطرها ε حجمها ε^d ضعف حجم كرة الوحدة تقريباً؛ وبناء شبكة جشعة نحصل على $\mathcal{N} \le (3/\varepsilon)^d$ (الثابت 3 لا 2 بسبب هندسة التغطية الجزئية). ■

الخطوة 2 (التسلسل الهرمي chaining): نكتب $f = f_0 + \sum_{k} (f_k - f_{k-1})$ حيث f_k من شبكة بمقياس 2^{-k}؛ ونحصر كلّ فرق بـ 2^{-k} وعدد عناصر الشبكة بـ $\mathcal{N}(2^{-k})$.

الخطوة 3 (اتّحاد على كلّ المستويات): نحصل على $\hat{\mathfrak{R}}_S \;\lesssim\; \sum_k 2^{-k} \sqrt{\ln \mathcal{N}(2^{-k})/n}$، والتقريب المتصل له هو تكامل (14.31). ■

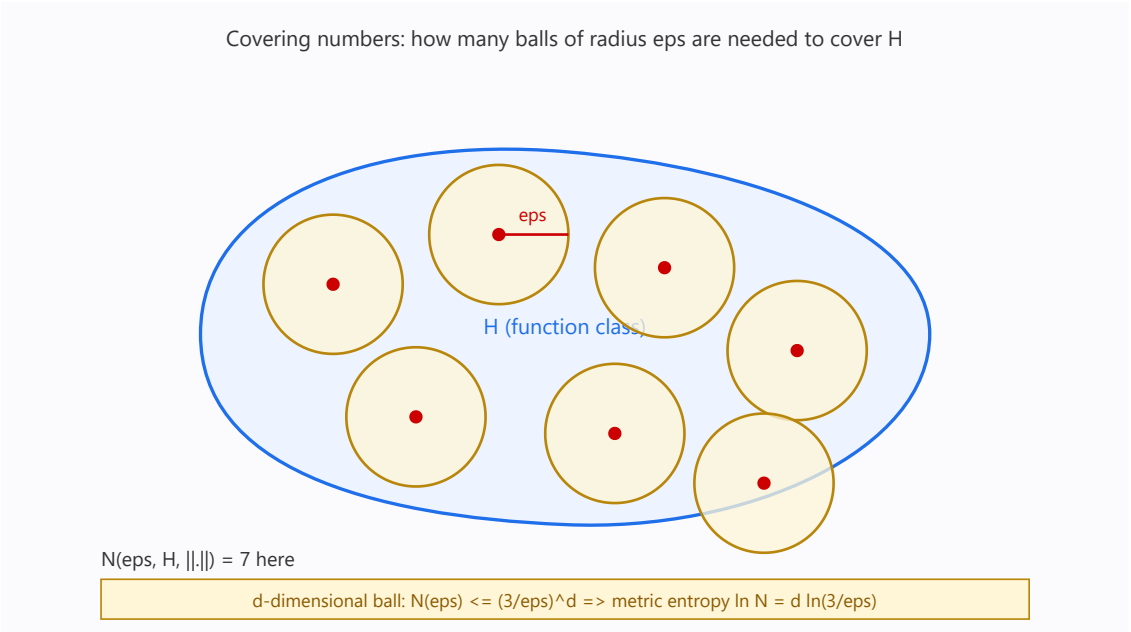
الخطوة 4 (المعايرة): بتعويض $\ln \mathcal{N} = d \ln(3/\varepsilon)$ في التكامل من 0 إلى 1:

$$\int_0^1 \sqrt{d}\, \sqrt{\ln 3 - \ln \varepsilon}\, d\varepsilon = \sqrt{d} \int_0^{\infty} \sqrt{\ln 3 + u}\; e^{-u} du \approx 1.43 \sqrt{d}$$

فينتج (15.31). ■

خمسة عشر مثالاً محلولاً

مثال (31-6.1): تغطية كرة في بعد عشرة المعطيات: $d = 10$، $\varepsilon = 0.1$. المطلوب: $\mathcal{N}$ والإنتروبيا. الحل: الخطوة 1: $(3/0.1)^{10} = 30^{10} = 5.90 \times 10^{14}$. الخطوة 2: $\ln \mathcal{N} = 10 \ln 30 = 34.02$. النتيجة: نحو 34 «نات» لوصف الفضاء عند هذه الدقّة. الربط بالذكاء الاصطناعي: الإنتروبيا المترية هي «عدد البتّات» الحقيقي لتعقيد النموذج.



شكل ٦.٣١: *
أرقام التغطية

مثال (6.31-2): تشديد الدقّة عشر مرّات المعطيات: $d = 10$، $\varepsilon = 0.01$. المطلوب: $\mathcal{N}$. الحل: الخطوة 1: $\ln \mathcal{N} = 57.87$، $(300)^{10} = 5.90 \times 10^{24}$. النتيجة: الدقّة بعشر مرّات أضافت $10 \ln 10 = 23$ ناتاً فقط (نموّ لوغاريتمي). الربط بالذكاء الاصطناعي: التكميم العددي (fp16/int8) يكلّف سعةً قليلة.

مثال (6.31-3): أثر مضاعفة الدقّة المعطيات: $d = 10$؛ من $\varepsilon = 0.2$ إلى $\varepsilon = 0.1$. المطلوب: الزيادة في الإنتروبيا. الحل: الخطوة 1: $\Delta = d \ln 2 = 6.93$ ناتاً. النتيجة: كلّ «بتّ دقّة» يكلّف $d \ln 2$ ناتاً. الربط بالذكاء الاصطناعي: قاعدة مباشرة لحساب تكلفة تقليل دقّة الأوزان.

مثال (6.31-4): تقدير التعقيد بـ Dudley المعطيات: $d = 10$، $n = 10^5$. المطلوب: $\hat{\mathfrak{R}}_S$ بـ (15.31). الحل: الخطوة 1: $17.2\sqrt{10/10^5} = 17.2\sqrt{10^{-4}} = 17.2(0.01) = 0.172$. النتيجة: تعقيد $\approx 0.17 \Rightarrow$ فجوة ≈ 0.34 بالحدّ (9.31). الربط بالذكاء الاصطناعي: رقم قابل للتصديق لمسائل رؤية متوسّطة الحجم.

مثال (6.31-5): مئة ضعف البيانات المعطيات: $d = 10$، $n = 10^6$. المطلوب: التعقيد. الحل: الخطوة 1: $17.2\sqrt{10/10^6} = 17.2(0.003162) = 0.0544$. (معامل $\sqrt{10} = 3.16$) النتيجة: من 0.172 إلى 0.054 (معامل $\sqrt{10} = 3.16$). الربط بالذكاء الاصطناعي: تأكيد معدّل $1/\sqrt{n}$ من منظور هندسي.

مثال (6.31-6): مقارنة مع حدّ VC المعطيات: $d = 10$، $n = 10^5$، $\delta = 0.05$. المطلوب: أيّهما أوثق؟ الحل: الخطوة 1: حدّ VC (6.31): $\sqrt{\frac{8}{10^5}(10 \ln(54366) + 4.38)} = \sqrt{8(113.4)/10^5} = 0.0952$. الخطوة 2: حدّ Rademacher: $2(0.172) + 0.0129 = 0.357$. النتيجة: حدّ VC أوثق هنا؛ لأنّ الثوابت في Dudley كبيرة. الربط بالذكاء الاصطناعي: الثوابت تقرّر النتيجة العملية لا الرتبة المقاربة فقط.

مثال (6.31-7): فضاء لانهائي البعد المعطيات: دالّات لبشيتزية على $[0,1]$ بثابت 1. المطلوب: سلوك الإنتروبيا. الحل: الخطوة 1: $\ln \mathcal{N}(\varepsilon) \asymp \frac{1}{\varepsilon}$ (لا $d \ln(1/\varepsilon)$). الخطوة 2: التكامل في (14.31) يعطي $\hat{\mathfrak{R}}_S \asymp n^{-1/3}$ بدل $n^{-1/2}$. النتيجة: الفضاءات اللانهائية البعد تتعلّم بمعدّل أبطأ — «لعنة الأبعاد» بهندستها. الربط بالذكاء الاصطناعي: يبرّر البحث عن تمثيلات منخفضة البعد (الفصل 35 وما بعده).

مثال (6.31-8): المتّجهات المتناثرة المعطيات: متّجهات k-متناثرة في $\mathbb{R}^d$ بـ $d = 1000$ و $k = 10$.

المطلوب: البعد الفعّال ورقم التغطية عند $\varepsilon = 0.1$. الحل: الخطوة 1: عدد الدعامات $\binom{1000}{10} \approx 2.6 \times 10^{23} \Rightarrow \ln \approx 54.3$ ناتاً. الخطوة 2: في كلّ دعامة: $10 \ln 30 = 34.0$ ناتاً. الخطوة 3: المجموع $(3/0.1)^{10} \Rightarrow 88.3 \approx$ ناتاً مقابل $1000 \ln 30 = 3408$ للفضاء الكامل. النتيجة: التناثر خفّض السعة بنحو 39 ضعفاً في الإنتروبيا. الربط بالذكاء الاصطناعي: التفسير الهندسي لنجاح L1 وتناثر النماذج.

مثال (9-6.31): كرة RKHS النووية المعطيات: كرة نصف قطرها R في فضاء Hilbert النووي بنواة محدودة. المطلوب: سلوك التغطية. الحل: الخطوة 1: إنتروبيا النواة تنمو ببطء (لوغاريتمياً للنواة الغاوسية: $\ln \mathcal{N} \asymp (\ln(1/\varepsilon))^{d+1}$). الخطوة 2: هذا أبطأ بكثير من أيّ قوّة في $1/\varepsilon$. النتيجة: أرقام التغطية تفسّر نجاح النواة حيث يعجز بُعد VC ($= \infty$). الربط بالذكاء الاصطناعي: أوضح مثال على أنّ «السعة» ليست عدداً واحداً.

مثال (10-6.31): موازنة حدّي Dudley المعطيات: $d = 10$، $n = 10^5$؛ نريد اختيار α في (14.31). المطلوب: القيمة المثلى تقريبياً. الحل: الخطوة 1: الحدّان: 4α و $[0, \alpha]$مساهمة $- 1.43\sqrt{d}) \frac{12}{\sqrt{n}}$. الخطوة 2: بأخذ α صغيراً جداً يصير الحدّ الأوّل تافهاً والثاني هو المهيمن. النتيجة: عملياً نضع $\alpha \approx 0$ للفضاءات المحدودة القطر. الربط بالذكاء الاصطناعي: تفصيل تقني لا يغيّر الاستنتاج العملي في معظم الحالات.

مثال (11-6.31): البعد الفعّال لشبكة عصبية المعطيات: شبكة بـ 10^7 معلمات لكنّ تمثيلاتها تقع على متعدّد بُعده الفعّال $100 \approx$. المطلوب: أثر ذلك على التغطية. الحل: الخطوة 1: بالبعد الفعّال: $\ln \mathcal{N} = 100 \ln(3/\varepsilon)$ عند $\varepsilon = 0.1$: 340 ناتاً. الخطوة 2: بالبعد الاسمي: $10^7 \ln 30 = 3.4 \times 10^7$ ناتاً. النتيجة: فرق بمئة ألف ضعف في الإنتروبيا. الربط بالذكاء الاصطناعي: قياس «البعد الفعّال للتمثيل» من أهمّ مقاييس تحليل الشبكات اليوم.

مثال (12-6.31): التغطية = ضغط المعطيات: فضاء بإنتروبيا $\ln \mathcal{N} = 100$ ناتاً. المطلوب: تفسير معلوماتي. الحل: الخطوة 1: 100 ناتاً $144 \approx$ بتّاً لوصف أيّ عنصر من الفضاء بدقّة ε. النتيجة: رقم التغطية يعطي «ميزانية وصف» صريحة للنموذج. الربط بالذكاء الاصطناعي: صلة مباشرة بمبدأ MDL من الفصل 28.

مثال (13-6.31): تقدير التغطية من البيانات المعطيات: عيّنة S وفضاء $\mathcal{F}$. المطلوب: حساب $\mathcal{N}(\varepsilon, \mathcal{F}, L_2(S))$ عملياً. الحل: الخطوة 1: نشغّل خوارزمية تغطية جشعة على قيم $\mathcal{F}$ المقيَّدة على S. الخطوة 2: نعدّ الكرات المطلوبة. النتيجة: رقم قابل للحساب لفضاءات محدودة العدد الفعّال. الربط بالذكاء الاصطناعي: يُستخدم في تحليل قدرات الشبكات تجريبياً.

مثال (14-6.31): Dudley مقابل ماسّار المعطيات: فضاء منتهٍ بـ $|\mathcal{F}| = 10^6$ ونفس الفضاء بوصفه بعداً فعّالاً $d = 20$. المطلوب: أيّ التقديرين أفضل عند $n = 10^4$؟ الحل: الخطوة 1: ماسّار: $\sqrt{2(13.816)/10^4} = 0.0526$. الخطوة 2: Dudley: $17.2\sqrt{20/10^4} = 17.2(0.0447) = 0.769$. النتيجة: هنا ماسّار أوثق بكثير (الفضاء المنتهي صغير). الربط بالذكاء الاصطناعي: اختر الأداة بحسب تمثيل الفضاء المتاح لك.

مثال (15-6.31): خلاصة المقارنة بين مقاييس السعة المعطيات: ثلاثة مقاييس: d_{VC} و $\hat{\mathfrak{R}}_S$ و $\ln \mathcal{N}$. المطلوب: متى نستخدم كلّاً؟ الحل: الخطوة 1: d_{VC}: لا يعتمد على البيانات ولا على التوزيع؛ جيد للمقارنات البنيوية. الخطوة 2: $\hat{\mathfrak{R}}_S$: يعتمد على العيّنة؛ أفضل حدّ عملي متى أمكن حسابه. الخطوة 3: $\ln \mathcal{N}$: يكشف البعد الفعّال؛ ممتاز للفضاءات النووية والمتناثرة. النتيجة: لا مقياس واحد يكفي؛ الثلاثة تكاملية. الربط بالذكاء الاصطناعي: هذا هو صندوق أدوات «تحليل السعة» في البحث المعاصر.

أخطاء شائعة

- استخدام $\mathcal{N}$ بالمعيار الخاطئ (يجب تحديد $L_2(S)$ أو L_∞ أو غيره).

- تجاهل أنّ (13.31) يفترض كرة وحدة في بعد منتهٍ.
- الخلط بين ε (دقّة التقريب) وγ (الهامش).
- اعتبار إنتروبيا أكبر = نموذج أسوأ دائماً (قد تكون مقابل تحيز أقلّ).
- تطبيق Dudley بثوابت حرفية في حسابات دقيقة (الثوابت تقريبية).

المبرهنة: عرّف خسارة الهامش عند مستوى $\gamma > 0$:

$$\ell_\gamma\big(h,(x,y)\big) \;=\; \min\Big(1,\; \max\big(0,\; 1 - \tfrac{y\,h(x)}{\gamma}\big)\Big) \tag{16.31}$$

وليكن $\mathcal{H} = \{x \mapsto w^\top x : \|w\|_2 \le B\}$ و $\max_i \|x_i\|_2 = R_x$. فباحتمال $\ge 1-\delta$:

$$R(h) \;\le\; \hat{R}_\gamma(h) \;+\; \frac{2\,B\,R_x}{\gamma\sqrt{n}} \;+\; 3\sqrt{\frac{\ln(2/\delta)}{2n}} \tag{17.31}$$

ولآلة نووية في فضاء Hilbert بـ $\|w\|_{\mathcal{H}} \le 1/\lambda$ و $k(x,x) \le \kappa$:

$$R(h) \;\le\; \hat{R}_\gamma(h) \;+\; \frac{2\sqrt{\kappa}}{\lambda\,\gamma\,\sqrt{n}} \;+\; 3\sqrt{\frac{\ln(2/\delta)}{2n}} \tag{18.31}$$

والأهمّ: **لا يظهر البعد d في الحدّ إطلاقاً.**

جدول الرموز

الرمز	المعنى	ملاحظة
γ	الهامش	ثقة الفصل
$y\,h(x)$	هامش النقطة	صحيح $\Leftarrow > 0$
$\hat{R}_\gamma$	خطر الهامش التجريبي	نسبة هامشها $< \gamma$
$B,\ R_x$	معيار الوزن ونصف قطر البيانات	يحلّان محلّ d
$1/\gamma$	ثابت لبشيتز لخسارة الهامش	في الانكماش
κ	سقف النواة $k(x,x)$	للآلات النووية

الرسم

<figure> الشكل<figcaption> 7.31: كلّما كبر الهامش صغرت السعة الفعّالة؛ وحدود الهامش تعتمد على γ و B و R_x لا على بُعد المُدخلات.</figcaption> </figure>

البرهان (مخطّط)

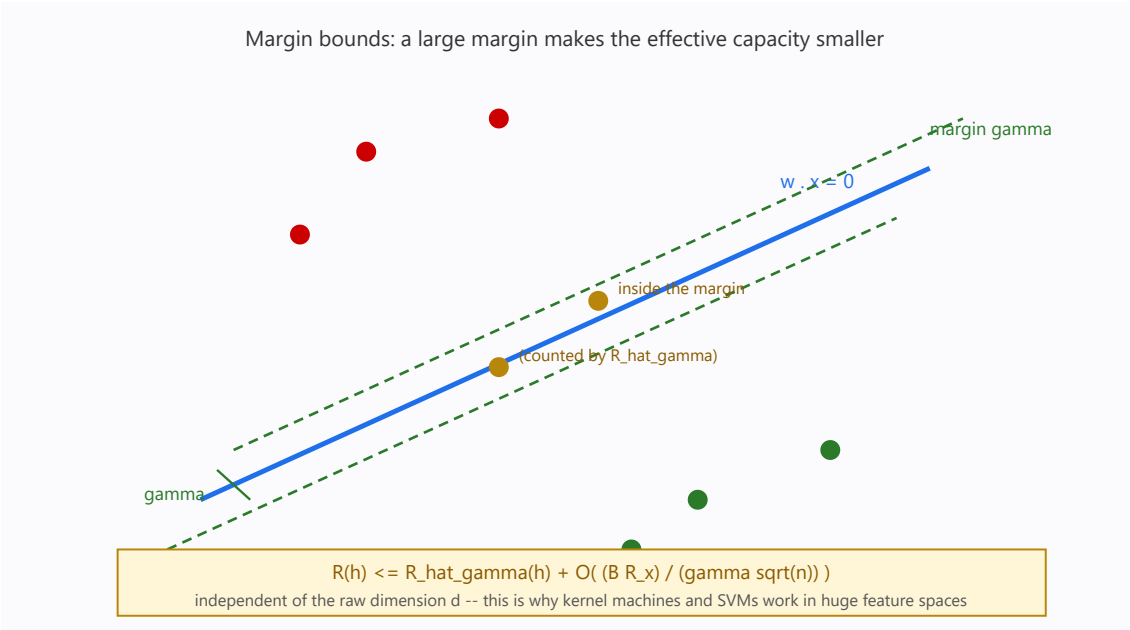
الخطوة 1: خسارة الهامش (16.31) لبشيتزية بثابت $1/\gamma$ في $y\,h(x)$، وتعلو خسارة 0-1: $\mathbf{1}[y h(x) \le 0] \le \ell_\gamma$.

الخطوة 2 (الانكماش): بمتراجحة الانكماش لتالاغراند: $\hat{\mathfrak{R}}_S(\ell_\gamma \circ \mathcal{H}) \le \frac{1}{\gamma}\hat{\mathfrak{R}}_S(\mathcal{H})$.

الخطوة 3 (تعقيد الصنف الخطّي): بـ (11.31): $\hat{\mathfrak{R}}_S(\mathcal{H}) \le B R_x/\sqrt{n}$ $\Rightarrow$ تعقيد المركّب $\le \frac{B R_x}{\gamma\sqrt{n}}$.

الخطوة 4 (التجميع): بتطبيق (9.31) على المركّب، مع ملاحظة أنّ $\mathbb{E}[\ell_\gamma] \ge R(h)$، نحصل على (17.31). ■

الخطوة 5 (النواة): بالممثّلة الرياضية: $\|w\|_{\mathcal{H}} \le 1/\lambda$ (من قيد الصندوق في الثنائية: $0 \le \alpha_i \le \frac{1}{\lambda n}$) و $\|x\|_{\mathcal{H}} = \sqrt{k(x,x)} \le \sqrt{\kappa}$ $\Rightarrow$ نطبّق (17.31) بـ $B = 1/\lambda$ و $R_x = \sqrt{\kappa}$ $\Rightarrow$ (18.31). ■



شكل ٧.٣١: *
حدود الهامش

خمسة عشر مثالاً محلولاً

مثال (1-7.31): حساب خسارة الهامش المعطيات: $\gamma = 1$، ثلاث نقاط بهوامش $y\,h(x) = 1.5,\ 0.6,\ -0.3$. المطلوب: خسائر الهامش. الحل: الخطوة 1: الأولى: $1 - 1.5 < 0 \Rightarrow \ell_\gamma = 0$. الخطوة 2: الثانية: $1 - 0.6 = 0.4 \Rightarrow \ell_\gamma = 0.4$. الخطوة 3: الثالثة: $1 + 0.3 = 1.3 \Rightarrow \min(1, 1.3) = 1$. النتيجة: النقاط داخل الهامش تُعاقب تدريجيّاً، والمصنّفة خطأً تُعاقب بالحدّ الأقصى. الربط بالذكاء الاصطناعي: الخسارة «المرنة» التي تجعل التحسين ممكناً.

مثال (2-7.31): حدّ بهامش كبير المعطيات: $B = 1$، $R_x = 1$، $\gamma = 0.5$، $n = 1000$، $\delta = 0.05$، $\hat{R}_\gamma = 0.10$. المطلوب: حدّ (17.31). الحل: الخطوة 1: $\frac{2(1)(1)}{0.5\sqrt{1000}} = \frac{2}{15.811} = 0.1265$. الخطوة 2: $3\sqrt{\ln 40/2000} = 3(0.04295) = 0.1289$. الخطوة 3: المجموع $= 0.10 + 0.1265 + 0.1289 = 0.3554$. النتيجة: حدّ غير فارغ (36.0) لنموذج خطّي بألف عيّنة. الربط بالذكاء الاصطناعي: حدود الهامش أوثق بكثير من حدود السعة في المسائل الخطّية.

مثال (3-7.31): أثر تضييق الهامش خمس مرّات المعطيات: كلّ شيء ثابت و $\gamma = 0.1$. المطلوب: الحدّ الجديد. الحل: الخطوة 1: $\frac{2}{0.1(31.62)} = 0.6326$. الخطوة 2: $+0.1289 \Rightarrow 0.8615 = 0.10 + 0.6326 + 0.1289$. النتيجة: الهامش الصغير كلّف 5.0 نقطة إضافية في الحدّ. الربط بالذكاء الاصطناعي: الهامش ليس تفصيلاً هندسيّاً بل موردٌ إحصائي.

مثال (4-7.31): تعويض الهامش بالبيانات المعطيات: $\gamma = 0.1$، $n = 10^5$. المطلوب: الحدّ. الحل: الخطوة 1: $\frac{2}{0.1(316.23)} = 0.0632$. الخطوة 2: $3(0.004295) = 0.0129$. الخطوة 3: المجموع $= 0.10 + 0.0632 + 0.0129 = 0.1761$. النتيجة: مئة ضعف البيانات دفعت ثمن الهامش الصغير. الربط بالذكاء الاصطناعي: «البيانات أو الهامش» مقايضة كمّية صريحة.

مثال (5-7.31): آلة نووية بسعة لانهائية المعطيات: $\kappa = 1$، $\lambda = 1$، $\gamma = 0.5$، $n = 1000$، $\hat{R}_\gamma = 0.08$. المطلوب: حدّ (18.31). الحل: الخطوة 1: $\frac{2\sqrt{1}}{1(0.5)(31.62)} = 0.1265$. الخطوة 2: $+0.1289 \Rightarrow$ المجموع 0.3354. النتيجة: حدّ مفيد رغم أنّ $d_{\mathrm{VC}} = \infty$! الربط بالذكاء الاصطناعي: الحلّ النظري لمفارقة النواة التي عجز عنها 12-2.31.

مثال (31.7-6): استقلال الحدّ عن البعد المعطيات: نفس المسألة في $\mathbb{R}^{10}$ ثمّ في $\mathbb{R}^{10^6}$. المطلوب: الفرق في الحدّ. الحل: الخطوة 1: الحدّ (31.17) لا يحتوي d إطلاقاً. الخطوة 2: الشرط الوحيد: B و R_x ثابتان. النتيجة: الانتقال من 10 إلى مليون بُعد لم يكلّف شيئاً نظريّاً. الربط بالذكاء الاصطناعي: التبرير النظري الأقوى لـ«حيلة النواة» (kernel trick).

مثال (31.7-7): اختيار مستوى الهامش بأفضلية الحدّ المعطيات: $n = 10^4$، $B = 1$، $R_x = 1$؛ $\hat{R}_{0.1} = 0.05$ و $\hat{R}_{0.5} = 0.30$. المطلوب: أيّ γ نختار؟ الحل: الخطوة 1: $\gamma = 0.1$: $\frac{2}{0.1(100)} = 0.2 \Rightarrow = 0.05 + 0.2 + 0.0407 = 0.2907$. الخطوة 2: $\gamma = 0.5$: $\frac{2}{0.5(100)} = 0.04 \Rightarrow 0.30 + 0.04 + 0.0407 = 0.3807$. النتيجة: نختار $\gamma = 0.1$ رغم أنّ خطره التجريبي أكبر. الربط بالذكاء الاصطناعي: المقايضة تُحسم بالحدّ الكامل لا بالخطأ التجريبي وحده.

مثال (31.7-8): تطبيع المدخلات ليس تجميلاً المعطيات: $B = 1$، $\gamma = 0.5$، $n = 1000$، $R_x = 100$ (بلا تطبيع) مقابل $R_x = 1$ (بعده). المطلوب: الحدّان. الحل: الخطوة 1: $R_x = 100$: $\frac{2(100)}{0.5(31.62)} = 12.65$ $\Rightarrow$ الحدّ فارغ تماماً. الخطوة 2: $R_x = 1$: $0.1265 \Rightarrow$ الحدّ مفيد. النتيجة: التطبيع غيّر الحدّ بمئة ضعف. الربط بالذكاء الاصطناعي: تفسير نظري لوجوب تطبيع المدخلات قبل التدريب.

مثال (31.7-9): التعزيز يرفع الهامش المعطيات: AdaBoost بـ $T = 100$ جولة؛ توزيع الهوامش يزحف نحو القيم الكبيرة. المطلوب: التفسير النظري لنجاحه رغم نموّ السعة. الحل: الخطوة 1: السعة (بُعد VC تنمو مع T؛ لكنّ الهامش يكبر أيضاً. الخطوة 2: حدّ الهامش (31.17) ينقص بزيادة $\gamma \Rightarrow$ قد يعوّض نموّ السعة. النتيجة: «التعزيز لا يُفرط في الملاءمة عادةً» ظاهرة لها تفسير هامشي مشهور. الربط بالذكاء الاصطناعي: من أوائل نجاحات نظرية الهامش في تفسير الممارسة.

مثال (31.7-10): هامش الشبكات بالمعايير الطيفية المعطيات: شبكة بـ $L = 3$ ومعايير طيفية $\|W_l\|_\sigma = 2$ لكلّ طبقة، $\gamma = 1$، $n = 10^4$، $R_x = 1$. المطلوب: صيغة الحدّ. الحل: الخطوة 1: «المعيار الفعّال» $B \approx \prod_l \|W_l\|_\sigma = 8$. الخطوة 2: $\frac{2(8)(1)}{1(100)} = 0.16$؛ $+0.0407 \Rightarrow$ الحدّ $0.2007 + \hat{R}_\gamma$. النتيجة: الحدّ محسوب من جداء المعايير لا من عدد الأوزان. الربط بالذكاء الاصطناعي: أصل التطبيع الطيفي والحدود المعيارية في الفصل 34.

مثال (31.7-11): هامش SVM الجامد المعطيات: بيانات قابلة للفصل خطّيّاً وآلة متّجهات داعمة (SVM) بهامش جامد؛ $\|w\| = 2$. المطلوب: الهامش الهندسي. الحل: الخطوة 1: الهامش $1/\|w\| = 0.5$. الخطوة 2: تعظيم الهامش $\Leftarrow$ تصغير $\|w\| \Leftarrow$ تنظيم L2 (الفصل 30). النتيجة: ربط مباشر بين التنظيم والهامش والحدّ. الربط بالذكاء الاصطناعي: SVM ليس إلا «تنظيماً + هامشاً» في صورة واحدة.

مثال (31.7-12): الهامش والضجيج المعطيات: بيانات بضجيج؛ نموذج يوسّع الهامش إلى أقصى حدّ. المطلوب: الخطر. الحل: الخطوة 1: تعظيم الهامش على بيانات ملوّثة يضحّي بملاءمة النقاط الصعبة. الخطوة 2: $\hat{R}_\gamma$ يرتفع $\Rightarrow$ قد يخسر الحدّ رغم نقصان $1/\gamma$. النتيجة: «الهامش الأكبر دائماً» قاعدة خاطئة في البيانات الملوّثة. الربط بالذكاء الاصطناعي: سبب استخدام SVM المرن (soft-margin) بـ C قابل للضبط.

مثال (31.7-13): الهامش مقابل بُعد VC في الأبعاد العالية المعطيات: $d = 10^4$، $n = 1000$، $\gamma = 0.3$، $B = 1$، $R_x = 1$. المطلوب: مقارنة الحدّين. الحل: الخطوة 1: حدّ الهامش: $\frac{2}{0.3(31.62)} = 0.2108 \Rightarrow$ مع التركيز ≈ 0.34. الخطوة 2: حدّ VC: $\Pi(2n) = 2^{2000}$ نستخدم $\Rightarrow d\ln(2en/d) = 10^4 \ln(0.5436) = -6104 < 0$ $\Rightarrow$ الحدّ $\sqrt{\frac{8}{1000}(1386 + 4.38)} = \sqrt{11.12} = 3.34$ فارغ. النتيجة: حدّ الهامش نجا حيث سقط حدّ السعة. الربط بالذكاء الاصطناعي: دليل على أهمّية اختيار المقياس المناسب للمسألة.

مثال (31.7-14): تعقيد العيّنة بالهامش المعطيات: $\gamma = 0.1$؛ نريد أن يكون حدّ الهامش ≤ 0.05. المطلوب: n. الحل: الخطوة 1: نشترط $\frac{2}{0.1\sqrt{n}} \leq 0.025$ (نصف الميزانية) $\Rightarrow \sqrt{n} \geq 800$. الخطوة 2: $n \geq 6.4 \times 10^5$. النتيجة: الهوامش الصغيرة مكلفة جدّاً في تعقيد العيّنة. الربط بالذكاء الاصطناعي: يفسّر الاهتمام بتحسين الهامش في تدريب

الشبكات الحديثة.

مثال (15-7.31): قياس توزيع الهامش عملياً المعطيات: شبكة مُدرَّبة على 50 ألف عيّنة. المطلوب: إجراء التشخيص. الحل: الخطوة 1: احسب $y\,h(x)$ لكلّ عيّنة تدريب (أو اللوجِت المُطَبَّع). الخطوة 2: ارسم التوزيع التراكمي؛ $\hat{R}_\gamma$ = نسبة ما دون γ. الخطوة 3: اختر γ الذي يصغّر الحدّ (17.31)، لا الذي يصغّر الخطأ فقط. النتيجة: أداة تشخيص مجانية تكشف الإفراط في الملاءمة مبكراً. الربط بالذكاء الاصطناعي: يُستخدم في أدوات تحليل النماذج وتفسيرها.

أخطاء شائعة

- استخدام الهامش على مخرجات غير مُطبَّعة (الهامش يعتمد على مقياس h).
- تجاهل أنّ $\hat{R}_\gamma$ يرتفع مع γ (المقايضة لا مجّانية).
- تطبيق (17.31) على شبكة بلا تقدير لـ B (يصير الحدّ بلا معنى).
- الخلط بين هامش SVM الجامد وهامش الحسارة في (16.31).
- افتراض أنّ تعظيم الهامش يقلّل الخطأ دائماً (قد يضرّ تحت الضجيج).

المبرهنة: لشبكة ReLU بـ W وزناً و L طبقات:

$$c\,W L \log\!\left(\tfrac{W}{L}\right) \;\le\; d_{\mathrm{VC}} \;\le\; C\,W L \log W \tag{19.31}$$

ولعدد القِطع الخطّية التي تحسبها شبكة بعرض n وعمق L على مُدخل أحادي البعد:

$$\#\text{pieces} \;\le\; (n+1)^{L}, \qquad \text{قِطعة } 2^{L} \Rightarrow L \text{ وببناء تِلغارسكي: عرض 2 وعمق} \tag{20.31}$$

ولتعقيد Rademacher بالمعايير الطيفية (صيغة مبسّطة من حدود بارتليت وآخرون):

$$\hat{\mathfrak{R}}_S(\mathcal{F}_{\text{net}}) \;\lesssim\; \frac{\|X\|_F}{\sqrt{n}} \prod_{l=1}^{L} \|W_l\|_\sigma \,\sqrt{L} \tag{21.31}$$

جدول الرموز

الرمز	المعنى	ملاحظة
W	عدد الأوزان	البعد الاسمي
L	عدد الطبقات	يضاعف السعة لوغاريتمياً
$\|W_l\|_\sigma$	المعيار الطيفي للطبقة	مقياس «تضخيمها»
$\prod_l \|W_l\|_\sigma$	جداء المعايير	يظهر في الحدود المعيارية
#pieces	القِطع الخطّية	مقياس تعبيريّة هندسي
d_{VC}	بُعد VC	$\gg W$ لكن ليس أسّياً فيه

البرهان (مخطّط)

الخطوة 1 (الحدّ السفلي لـ d_{VC}): شبكة بوحدات ترجيح و W وزناً تحطّم W نقطة ببناء صريح $\Rightarrow d_{\text{VC}} \geq W$. ولـ ReLU توجد بناءات تعطي $\Omega(WL\log(W/L))$.

الخطوة 2 (الحدّ العلوي): كلّ طبقة ReLU تقسّم فضاء المعلمة إلى مناطق متعدّدة الحدود، وعدد التوقيعات الممكنة محدود بعدد القِطع، فيُحسب الحدّ العلوي $O(WL\log W)$ بعدّ القِطع وضربها في سعة كلّ قِطعة.

الخطوة 3 (القِطع الخطّية): بالاستقراء على الطبقات: كلّ طبقة بعرض n في بُعد واحد تضاعف عدد القِطع بعامل $\leq n+1$ $\Rightarrow (n+1)^L$. وبناء تِلغارسكي للموجة المثلّثة يعطي 2^L بعرض 2 $\Rightarrow$ العمق أُسّي والعرض خطّي. ■

الخطوة 4 (المعياري): بتطبيق (11.31) طبقةً طبقة مع لبشيتزية كلّ طبقة $\|W_l\|_\sigma$ والانكماش $\Rightarrow$ جداء المعايير، ومعامل $\sqrt{L}$ من تراكم الطبقات. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.31): حدّ سفلي لشبكة بوحدات ترجيح المعطيات: $W = 10^6$ وزناً. المطلوب: حدّ أدنى لـ d_{VC}. الحل: الخطوة 1: $d_{\text{VC}} \geq W = 10^6$. النتيجة: مليون بعد معلوماتي على الأقل. الربط بالذكاء الاصطناعي: كلّ وزن قادر على «حمل» وسم مستقلّ.

مثال (2-8.31): حدّ علوي لشبكة ReLU المعطيات: $W = 10^6$، $L = 10$. المطلوب: الحدّ العلوي بـ (19.31). الحل: الخطوة 1: $\log W = \ln(10^6) = 13.82$. الخطوة 2: $WL\log W = 10^6(10)(13.82) = 1.38 \times 10^8$. النتيجة: نحو 138 مليون — أكبر من W بمئة وثمانية وثلاثين ضعفاً. الربط بالذكاء الاصطناعي: السعة أكبر من عدد المعلمات لكنها ليست أسّية فيه.

مثال (3-8.31): كم عيّنة يحتاج الحدّ ليصير غير فارغ؟ المعطيات: $d = 1.38 \times 10^8$ من المثال السابق. المطلوب: n الذي يجعل $\frac{8}{n}\big(d\ln(2en/d) + \ln 80\big) \leq 1$ (6.31) أقلّ من 1. الحل: الخطوة 1: نشترط $\frac{8}{n}(8.25 \times 10^8) = 0.66 \Rightarrow d\ln = 8.25 \times 10^8 \Rightarrow \ln = 5.98 \Rightarrow 2en/d = 394$: عند $n = 10^{10}$. الخطوة 2: $\frac{8}{10^9}(5.07 \times 10^8) = 4.06 \Rightarrow$ الجذر $1 < 2.01 \times$. النتيجة: نحو 10^{10} عيّنة — أي عشرة مليارات. الربط بالذكاء الاصطناعي: دليل قاطع على أنّ حدود السعة لا تفسّر نجاح الشبكات (بوابة الفصل 34).

مثال (4-8.31): قوّة العمق الأُسّية المعطيات: شبكتان: (أ) عرض 2 وعمق 10؛ (ب) عرض 1024 وعمق 1؛ مُدخل أحادي البعد. المطلوب: مقارنة التعبيريّة والتكلفة. الحل: الخطوة 1: (أ) تنتج $2^{10} = 1024$ قِطعة بـ ≈ 30 وزناً. الخطوة 2: (ب) تنتج 1024 قِطعة بـ ≈ 2048 وزناً. الخطوة 3: النسبة في عدد المعلمات ≈ 68 $2048/30$. النتيجة: العمق يمنح نفس التعبيريّة بتكلفة أقلّ بمرتين من حيث الرتبة. الربط بالذكاء الاصطناعي: التبرير النظري الأول لنجاح الشبكات العميقة على الضحلة.

مثال (5-8.31): نموّ القِطع مع العمق المعطيات: عرض $n = 100$، عمق $L = 5$، مُدخل أحادي البعد. المطلوب: أقصى عدد القِطع. الحل: الخطوة 1: $(n+1)^L = 101^5 = 1.05 \times 10^{10}$. النتيجة: عشرة مليارات قِطعة خطّية من $\approx 5 \times 10^4$ وزن. الربط بالذكاء الاصطناعي: التعبيريّة تنفجر مع العمق — والسعة كذلك.

مثال (6-8.31): البعد الفعّال للتمثيلات المعطيات: شبكة رؤية بـ 10^7 معلمات، تمثيلاتها تُقاس ببعد جوهري ≈ 100. المطلوب: أثر ذلك على التغطية عند $\varepsilon = 0.1$. الحل: الخطوة 1: بالبعد الفعّال: $\ln \mathcal{N} = 100\ln 30 = 340$ ناتاً. الخطوة 2: بالبعد الاسمي: $10^7 \ln 30 = 3.4 \times 10^7$ ناتاً. النتيجة: فرق بمئة ألف ضعف. الربط بالذكاء الاصطناعي: «البعد الجوهري» مقياس عملي أهمّ من عدد المعلمات.

مثال (31.8-7): حدّ معياري بالأرقام المعطيات: $\|X\|_F/\sqrt{n} = 1$، $\prod_l \|W_l\|_\sigma = 8$، $L = 3$، $\gamma = 0.5$، $n = 10^4$. المطلوب: حدّ الهامش المعياري. الحل: الخطوة 1: تعقيد الشبكة بـ (31.21): $\sqrt{3} \times 8 \times 1 = 13.86$. الخطوة 2: بعد الانكماش بالهامش: $\frac{2}{\gamma}(13.86)/\sqrt{n}$... بصيغة (31.17): $\frac{2BR_x}{\gamma\sqrt{n}}$ مع $B \approx 8 \Rightarrow \frac{16}{0.5(100)} = 0.32$. الخطوة 3: $\hat{R}_\gamma + 0.0407 \Rightarrow$ الحدّ 0.361. النتيجة: حدّ غير فارغ هذه المرّة — بفضل صغر جداء المعايير. الربط بالذكاء الاصطناعي: التحكّم في المعايير الطيفية يجعل الحدود قابلة للاستخدام.

مثال (31.8-8): أثر التطبيع الطيفي المعطيات: جداء المعايير من 300 إلى 8. المطلوب: تحسّن الحدّ. الحل: الخطوة 1: الحدّ يتناسب طرديّاً مع الجداء. الخطوة 2: النسبة $300/8 = 37.5$. النتيجة: تحسّن بسبعة وثلاثين ضعفاً في الحدّ النظري. الربط بالذكاء الاصطناعي: تبرير قوي لانتشار Spectral Normalization في GAN والتدريب المستقرّ.

مثال (31.8-9): اضمحلال الوزن يقلّص السعة المقيسة المعطيات: تدريب بـ decay weight $\lambda = 10^{-4}$ مقابل $\lambda = 0$. المطلوب: الأثر المتوقّع على جداء المعايير. الحل: الخطوة 1: الاضمحلال يحدّ من نموّ الأوزان $\Rightarrow$ يحدّ من المعايير الطيفية. الخطوة 2: قياس الجداء قبل وبعد يعطي مؤشّراً قابلاً للتتبّع أثناء التدريب. النتيجة: مقياس عملي للسعة يمكن مراقبته لا حسابه تحليليّاً فقط. الربط بالذكاء الاصطناعي: أدوات المراقبة الحديثة تقيس هذه الكمّيات فعلاً.

مثال (31.8-10): عدد المعلمات ليس السعة المعطيات: شبكتان: $W = 10^5$ و $W = 10^7$ على نفس المسألة. المطلوب: هل يتوقّع حدّ السعة تدهوراً بمئة ضعف؟ الحل: الخطوة 1: d_{VC} يتضخّم بمئة ضعف $\Rightarrow$ الحدّ يزداد بـ $\sqrt{100} = 10$. الخطوة 2: لكنّ الأداء الفعلي لا يتدهور بل يتحسّن غالباً. النتيجة: تناقض صريح بين النظرية والممارسة = مفارقة المعلمات الزائدة. الربط بالذكاء الاصطناعي: هذه المفارقة هي عنوان الفصل 34.

مثال (31.8-11): الضغط بوصفه سعة المعطيات: شبكة يمكن تقليمها إلى $k = 10^4$ معلمة مع خطأ $\gamma = 0.05$، $n = 10^6$. المطلوب: حدّ التعميم بالضغط. الحل: الخطوة 1: حدّ الضغط: $R \lesssim \gamma + \tilde{O}(\sqrt{k/n})$. الخطوة 2: $\sqrt{10^4/10^6} = \sqrt{0.01} = 0.1$. الخطوة 3: المجموع $0.15 = 0.1 + 0.05 \approx$. النتيجة: حدود الضغط قد تكون غير فارغة حيث حدود VC فارغة. الربط بالذكاء الاصطناعي: أساس نظري لتقليم النماذج وتكميمها في النشر على الأجهزة.

مثال (31.8-12): تصوير طبي ببيانات قليلة المعطيات: $n = 2000$ صورة، شبكة بـ 2.5×10^7 معلمات و $L = 24$. المطلوب: تقييم واقعي. الحل: الخطوة 1: $p/n = 12500$ معلمة لكلّ عيّنة $\Rightarrow$ حدود السعة فارغة تماماً. الخطوة 2: الاعتماد على التدريب المسبق (pretraining) والتنظيم القوي وتكثير البيانات إلزامي. النتيجة: في هذا النظام، «البيانات الطبيعية» هي التنظيم الحقيقي. الربط بالذكاء الاصطناعي: يفسّر لماذا يُعدّ نقل التعلّم معياراً في التصوير الطبي لا خياراً.

مثال (31.8-13): نماذج لغوية ضخمة المعطيات: نموذج بـ $W = 10^{11}$؛ بيانات $n = 2 \times 10^{12}$ رمزاً. المطلوب: مقارنة النظام التجريبي بالحدّ النظري. الحل: الخطوة 1: النسبة العملية $n/W = 20$ (تقارب قوانين التوسّع الحديثة). الخطوة 2: الحدّ النظري يتطلّب $n \gtrsim d \approx WL\log W \approx 10^{11}(100)(25.3) = 2.5 \times 10^{14}$. الخطوة 3: النسبة بين المطلوب نظريّاً والمستخدم فعليّاً ≈ 125. النتيجة: الممارسة تسبق النظرية بمرتبتين من حيث حجم البيانات. الربط بالذكاء الاصطناعي: «قوانين التوسّع» تجريبية وليست مشتقّة من حدود السعة — بعدُ بحث مفتوح.

مثال (31.8-14): أمن سيبراني — هل نحتاج سعة هائلة؟ المعطيات: كشف تسلّل بحدود قرار معقّدة جدّاً. المطلوب: موازنة السعة والبيانات. الحل: الخطوة 1: الحدود المعقّدة تتطلّب سعة (تقليل التحيز). الخطوة 2: لكنّ السعة ترفع التباين، والفئة النادرة (0.1%) تجعل حجم العيّنة الفعّال $n \times 10^{-3} \approx$. النتيجة: في الأمن، «حجم العيّنة الفعّال» هو القيد الحاكم لا السعة. الربط بالذكاء الاصطناعي: يبرّر الاعتماد على قواعد + نموذج هجين لا على سعة وحدها.

مثال (31.8-15): ماذا نستخدم إذاً في الممارسة؟ المعطيات: مشروع صناعي عادي. المطلوب: خطة تقييم السعة والتعميم. الحل: الخطوة 1: لا تعتمد على حدود VC/Rademacher لتقدير الأداء (فضفاضة أو فارغة). الخطوة 2:

استخدمها موجّهاً: هل نزيد البيانات أم السعة أم التنظيم؟ الخطوة 3: احسب الأداء بالتحقق المتقاطع (الفصل 30) والاستقرار (الفصل 33). الخطوة 4: للشبكات العميقة استخدم أدوات الفصل 34، PAC-Bayes) الضغط، المعايير). النتيجة: خريطة استخدام لا خريطة اعتقاد. الربط بالذكاء الاصطناعي: هذه هي الحكمة العملية التي ينتجها هذا الجزء من الكتاب.

أخطاء شائعة

- مساواة عدد المعلمات ببُعد VC (الفرق معامل $L \log W$ على الأقل).
- توقّع تدهور التعميم من مجرّد زيادة المعلمات (المفارقة تنفي ذلك).
- تطبيق (21.31) بلا تقدير موثوق لجداء المعايير.
- تجاهل أنّ العمق يضاعف التعبيريّة أُسّيّاً (ليس خطّيّاً).
- الاستنتاج أنّ «النظرية عاجزة» بدل «هذا المقياس غير مناسب لهذه المسألة».

ملخّص النظريات

النظرية	المفهوم	الأهمّية
2.31 التحطيم وبُعد VC	d_{VC} = أكبر مجموعة محطومة	مقياس السعة للفضاءات غير المنتهية
3.31 Sauer–Shelah	$\Pi(m) \le \sum_{i=0}^{d} \binom{m}{i}$	النموّ كثير حدود لا أسّي
4.31 مبرهنة التأسيس	$R \le \hat{R} + \sqrt{\frac{8}{n}(d \ln \frac{2en}{d} + \ln \frac{4}{\delta})}$	$n = O(d/\varepsilon^2)$
5.31 Rademacher	$\hat{\mathfrak{R}}_S = \mathbb{E}_\sigma \sup_f \frac{1}{n} \sum \sigma_i f$	حدود تعتمد على البيانات
6.31 التغطية و Dudley	$\mathcal{N} \le (3/\varepsilon)^d$	الإنتروبيا المترية والبعد الفعّال
7.31 الهامش	$R \le \hat{R}_\gamma + \frac{2BR_x}{\gamma\sqrt{n}}$	استقلال عن البعد
8.31 الشبكات	$d_{\mathrm{VC}} = \Theta(WL \log W)$	لماذا تعجز حدود السعة؟

عشرون تمريناً (مع إجابات مختصرة)

١. تعريف التحطيم؟ ($|\mathcal{H}|_S| = 2^m$)

٢. d_{VC} لنصف فضاءات في $\mathbb{R}^d$؟ ($d+1$)

٣. d_{VC} للفترات على $\mathbb{R}$؟ (2)

٤. d_{VC} للمستطيلات المحورية في $\mathbb{R}^2$؟ (4)

٥. d_{VC} لـ 1-NN؟ (∞)

٦. صيغة Sauer؟ ($\sum_{i=0}^{d} \binom{m}{i}$)

٧. الصيغة المريحة لدالّة النموّ؟ ($(em/d)^d$)

٨. متى $\Pi(m) = 2^m$؟ (عند $m \le d$)

٩. حدّ فابنيك–تشروننكيس؟ ($\sqrt{\frac{8}{n} \ln \frac{4\Pi(2n)}{\delta}}$)

١٠. تعقيد العيّنة؟ ($n = O((d + \ln(1/\delta))/\varepsilon^2)$)

١١. تعريف تعقيد Rademacher؟ $\left(\mathbb{E}_\sigma \sup_f \frac{1}{n}\sum \sigma_i f\right)$

١٢. ماسّار للفضاء المنتهي؟ $\left(\sqrt{2\ln|\mathcal{F}|/n}\right)$

١٣. تعقيد الصنف الخطّي؟ $\left(BR_x/\sqrt{n}\right)$

١٤. رقم تغطية كرة الوحدة؟ $\left((3/\varepsilon)^d\right)$

١٥. مقياس Dudley؟ $\left(\approx 17\sqrt{d/n}\right)$

١٦. خسارة الهامش؟ $\left(\min(1, \max(0, 1 - yh/\gamma))\right)$

١٧. حدّ الهامش؟ $\left(\hat{R}_\gamma + 2BR_x/(\gamma\sqrt{n})\right)$

١٨. لماذا لا يظهر d في حدّ الهامش؟ (لأنّه يقيس B و R_x لا البعد)

١٩. d_{VC} لشبكة ReLU؟ $\left(O(WL\log W)\right)$

٢٠. لماذا حدود السعة فارغة للشبكات العميقة؟ (لأنّ $d \gg n$)

فهرس الرموز

الرمز	المعنى
d_{VC}	بُعد فابنيك–تشروننكيس
$\Pi_{\mathcal{H}}(m)$	دالّة النموّ
σ_i	إشارات رادِماخر
$\hat{\mathfrak{R}}_S$	تعقيد Rademacher التجريبي
$\mathcal{N}(\varepsilon)$	رقم التغطية
γ	الهامش
$B,\ R_x$	معيار الوزن ونصف قطر البيانات
$\|W_l\|_\sigma$	المعيار الطيفي للطبقة

مراجع

- Chervonenkis & Vapnik — "On the Uniform Convergence of Relative Frequencies" (1971).
- Vapnik — *Statistical Learning Theory* (1998) — مبرهنة التأسيس و SRM.
- Sauer — "On the Density of Families of Sets" (1972)؛ Shelah (1972) — مبرهنة الاستقرار.
- Bartlett & Mendelson — "Rademacher and Gaussian Complexities" (2002).
- Massart — "Some Applications of Concentration Inequalities" (2000).
- Dudley — "The Sizes of Compact Subsets of Hilbert Space" (1967) — متراجحة التسلّسل.
- Kolmogorov & Tikhomirov — "ε-Entropy and ε-Capacity" (1959).
- Bartlett, Harvey, Liaw, Mehrabian & Telgarsky — "Nearly-tight VC-dimension Bounds for Piecewise Linear Neural Networks" (2019).

- Telgarsky — «Benefits of Depth in Neural Networks» (2016).
- Pascanu, Montúfar, Bengio & Cho — «On the Number of Linear Regions of Deep Neural Networks» (2014).
- Ben-David & Shalev-Shwartz — *Understanding Machine Learning* (الفصول 6 و 13 و 14).
- Mohri, Rostamizadeh & Talwalkar — *Foundations of Machine Learning* (الفصول 3 و 4 و 5).

خاتمة: أعطانا هذا الفصل مقياساً للسعة يعمل في الفضاءات غير المنتهية، لكنّه كشف حدّه: بُعد VC **لا يعتمد على الخوارزمية ولا على التوزيع**، فلا يفسّر لماذا تعمّم خوارزميةٌ ولا تعمّم أخرى على البيانات نفسها. الفصل 32 يعالج هذا من زاوية مختلفة: **إطار PAC** — ماذا يعني أن تكون فئةٌ «قابلة للتعلّم» أصلاً، وكم عيّنة يلزم ذلك بالضبط؟

نظرية PAC والتعلّم القابل للتعلّم

«ليس السؤال: هل يتعلّم؟ بل: كم عيّنة يلزمه، وهل يمكن حسابها؟»

الفصل 31 أعطانا مقياساً للسعة، لكنّ سؤاله كان ضمنياً: «متى يقترب الخطر التجريبي من الخطر؟». هذا الفصل يطرح السؤال في صورته الأصلية التي صاغها **ليزلي فاليانت** سنة 1984: ما معنى أن تكون فئةٌ ما **قابلة للتعلّم** أصلاً، وكم عيّنة تكفي لذلك، وهل يمكن حساب الفرضية في وقت معقول؟ سنرى أنّ بُعد VC — الذي درسناه في الفصل 31 — **يُصنّف** المسألة تصنيفاً تامّاً: فئةٌ قابلة للتعلّم بـ PAC إذا وفقط إذا كان بُعدها منتهياً. ثمّ ندرس الحالة الواقعية (غير المتحيّزة)، والحدود السفلية التي تمنع أيّ خوارزمية من التفوّق، وتعقيد العيّنة لفئات بعينها، والتعزيز (من متعلّم ضعيف إلى قوي)، وأخيراً التعقيد **الحسابي** الذي يفصل بين «ممكن إحصائيّاً» و«ممكن عمليّاً».

سبع نظريات:

- **2.32 إطار PAC الرسمي** — تعريف «التعلّم» الدقيق.
- **3.32 مبرهنة التأسيس لـ PAC** — بُعد VC المنتهي $\Leftrightarrow$ قابلية التعلّم.
- **4.32 التعلّم غير المتحيّز (agnostic)** — حين لا يحتوي $\mathcal{H}$ الحقيقة.
- **5.32 حدود سفلى لتعقيد العيّنة** — ما لا تستطيع أيّ خوارزمية تجاوزه.
- **6.32 تعقيد العيّنة لفئات محدّدة** — من العتبات إلى الأشجار.
- **7.32 الضعيف = القوي: التعزيز في إطار PAC** — تضخيم متعلّم ضعيف.
- **8.32 التعقيد الحسابي للتعلّم** — حين تعجز الحسابات لا الإحصاء.

كل نظرية تتبع القالب الرباعي: صياغة رسمية $\longleftarrow$ جدول رموز $\longleftarrow$ رسم $\longleftarrow$ برهان $\longleftarrow$ خمسة عشر مثالاً $\longleftarrow$ أخطاء شائعة.

الرمز	المعنى	ملاحظة
ε	حدّ الخطأ المسموح (accuracy parameter)	«تقريباً» approximately
δ	احتمال الفشل (confidence parameter)	«على الأرجح» probably
A	خوارزمية التعلّم $A : S \mapsto h$	قد تكون عشوائية
$\mathcal{D}$	توزيع مجهول على $\mathcal{X} \times \mathcal{Y}$	distribution-free
$m_{\mathcal{H}}(\varepsilon, \delta)$	تعقيد العيّنة	أصغر n يكفي
تحقّقي (realizable)	توجد $h^\star \in \mathcal{H}$ بخطأ صفر	افتراض قوي
غير متحيّز (agnostic)	بلا افتراض عن الحقيقة	الواقع
صحيح (proper)	مخرجات A من $\mathcal{H}$	
غير صحيح (improper)	قد تخرج من خارج $\mathcal{H}$	أقوى أحياناً
كفء (efficient)	زمن حدودي في $1/\varepsilon, 1/\delta, d$	البعد الحسابي

الاتفاقيات: التصنيف الثنائي بخسارة 0-1، و«قابل للتعلّم» تعني distribution-free (لكلّ توزيع) ما لم نذكر خلاف ذلك. نرمز n لحجم العيّنة و d لبُعد VC.

التعريف: لتكن $\mathcal{H}$ فئة فرضيات و $\varepsilon, \delta \in (0,1)$. نقول إنّ خوارزمية A **تتعلّم** $\mathcal{H}$ **بـ PAC** إذا وُجدت دالّة $m_{\mathcal{H}}(\varepsilon,\delta)$ بحيث أنّ لكلّ توزيع $\mathcal{D}$ ولكلّ ε,δ، عند سحب عيّنة $S \sim \mathcal{D}^n$ بحجم $n \geq m_{\mathcal{H}}(\varepsilon,\delta)$:

$$\mathbb{P}_{S\sim\mathcal{D}^n}\Big[\, R_{\mathcal{D}}\big(A(S)\big) \;\leq\; \varepsilon \,\Big] \;\geq\; 1-\delta \tag{1.32}$$

في الحالة **التحقّقية** (توجد $h^\star \in \mathcal{H}$ بـ $R(h^\star)=0$)، وفي الحالة **غير المتحيّزة** يستبدل الشرط بـ

$$\mathbb{P}\Big[\, R\big(A(S)\big) \;\leq\; \inf_{h\in\mathcal{H}} R(h) + \varepsilon \,\Big] \;\geq\; 1-\delta \tag{2.32}$$

وتعقيد العيّنة هو أصغر دالّة تحقّق ذلك:

$$m_{\mathcal{H}}(\varepsilon,\delta) \;=\; \min\Big\{ n : \; A \text{ لكلّ } \mathcal{D} \text{ تحقّق } (1.32) \Big\} \tag{'2.32}$$

جدول الرموز

الرمز	المعنى	ملاحظة
ε	هامش الخطأ	تقريباً
δ	احتمال الاستثناء	على الأرجح
$1-\delta$	الثقة	95% تعني $\delta=0.05$
لكلّ $\mathcal{D}$	distribution-free	أقوى أنواع الضمان
تحقّقي	الصفر attainable	يُتيح معدّلاً أسرع
غير متحيّز	مقارنة بأفضل ما في $\mathcal{H}$	الواقع العملي

الرسم

<figure>

<figcaption>الشكل 1.32: التعلّم بـ PAC يعني أنّ منحنى الخطر ينزل تحت ε باحتمال $1-\delta$ متى تجاوز حجم العيّنة $n(\varepsilon,\delta)$.</figcaption>
</figure>

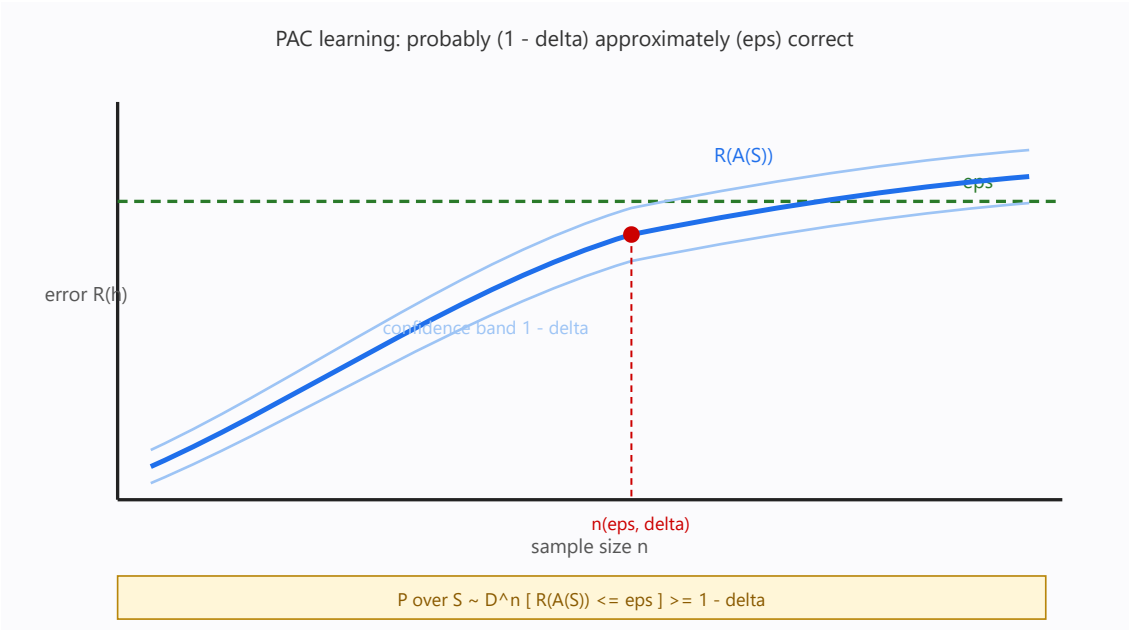
البرهان (تأسيسي)

الخطوة 1 (توضيح الاحتمال): الاحتمال في (1.32) على **سحب العيّنة** S (وربّما على عشوائية الخوارزمية)، لا على نقطة اختبار واحدة.

الخطوة 2 (distribution-free): الضمان يجب أن يصحّ **لكلّ** $\mathcal{D}$، وترتيب الكمّيات: أوّلاً نثبّت ε,δ، ثمّ نقيس على أسوأ توزيع.

الخطوة 3 (الصلة بالفصل 31): إذا كان $\sup_h |R - \hat{R}| \leq \varepsilon/2$ باحتمال $1-\delta$ و $\hat{R}(\hat{h})=0$ (تحقّقي)، فإنّ $R(\hat{h}) \leq \varepsilon/2 \leq \varepsilon$ ⇐ إطار PAC يكفيه تقاربٌ موحّد بمقدار $\varepsilon/2$.

الخطوة 4 (لماذا «تقريباً»؟): لأنّ التعلّم من عيّنة منتهية لا يمكن أن يضمن الخطأ الصفر إلّا في حالات نادرة، ولأنّ الضجيج قد يجعل $R^\star > 0$. ■



شكل ١٠٣٢: *
إطار PAC

خمسة عشر مثالاً محلولاً

مثال (1-2.32): تصفية البريد المزعج المعطيات: نريد خطأ $\leq 5\%$ بثقة 95%. المطلوب: ترجمة ذلك إلى (ε, δ). الحل: الخطوة 1: $\varepsilon = 0.05$، $\delta = 0.05$. الخطوة 2: المطلوب: من 100 سحبة للعيّنة، تنجح 95 على الأقل. النتيجة: التزام قابل للقياس لا وعد غامض. الربط بالذكاء الاصطناعي: هذه هي اللغة التي تُكتب بها عقود مستوى الخدمة (SLA).

مثال (2-2.32): تشخيص طبي بحدود أمان المعطيات: خطأ $\leq 1\%$ بثقة 99%. المطلوب: المعاملات. الحل: الخطوة 1: $\varepsilon = 0.01$، $\delta = 0.01$. الخطوة 2: أشدّ بـ 5 و 5 مرّات من المثال السابق. النتيجة: التكلفة في حجم العيّنة ستكون كبيرة جدّاً (انظر 3.32). الربط بالذكاء الاصطناعي: الأنظمة الطبية تحتاج تصميماً إحصائيّاً قبل المعمارية.

مثال (3-2.32): تفكيك «على الأرجح، تقريباً صحيح» المعطيات: تقرير «دقّة 92%». المطلوب: هل هو ادّعاء PAC؟ الحل: الخطوة 1: «تقريباً» = ε، «على الأرجح» = $1 - \delta$. الخطوة 2: التقرير بلا δ $\Rightarrow$ ادّعاء ناقص. النتيجة: كلّ رقم أداء يحتاج معاملَي ثقة. الربط بالذكاء الاصطناعي: سبب إلزام المجلّات بفترات ثقة في النتائج.

مثال (4-2.32): رتابة تعقيد العيّنة المعطيات: $m(0.1, 0.05) = 1000$. المطلوب: هل $m(0.05, 0.05) \geq 1000$؟ الحل: الخطوة 1: تصغير ε يجعل المطلوب أصعب $\Rightarrow$ m لا ينقص. الخطوة 2: وكذلك تصغير δ. النتيجة: m غير متناقصة في كلا المعاملين (بالمعنى المعكوس). الربط بالذكاء الاصطناعي: قيد تصميمي بديهي لكنّه قابل للإثبات.

مثال (5-2.32): هل افتراض التحقّق واقعي؟ المعطيات: تصنيف صور قطط وكلاب بوسوم بشريّة. المطلوب: هل المسألة تحقّقية؟ الحل: الخطوة 1: الصور المتشابهة قد تُوسم dffierently (ضجيج في الوسم). الخطوة 2: إذن لا توجد فرضية بخطأ صفر $\Rightarrow$ المسألة غير متحيّزة. النتيجة: الافتراض غير المتحيّز هو الافتراض الافتراضي في التطبيق. الربط بالذكاء الاصطناعي: سبب شيوع الخسائر المرنة (hinge، CE) على الخسائر الجامدة.

مثال (6-2.32): distribution-free يعني الأسوأ المعطيات: ضمان PAC على كلّ التوزيعات. المطلوب: ما ثمن ذلك؟ الحل: الخطوة 1: الضمان يجب أن يصحّ للتوزيعات المركّزة على نقاط قليلة (الأسوأ). الخطوة 2: هذا يجعل الحدود متحفّظة على التوزيعات «اللطيفة». النتيجة: حدود PAC محافظة بطبعها؛ قد تكون البيانات أسهل. الربط بالذكاء

الاصطناعي: يبرّر الحدود المعتمدة على البيانات (الفصل 31 والفصل 34).

مثال (32.2-7): توزيع ثابت أسهل المعطيات: نعرف أنّ $\mathcal{D}$ منتظم على كرة الوحدة. المطلوب: هل نحتاج نفس n؟ الحل: الخطوة 1: التعلّم **بتوزيع ثابت** أسهل من distribution-free. الخطوة 2: يمكن استغلال بنية التوزيع (تماثل، كثافة) لتقليل n. النتيجة: حدود «الاستقلال عن التوزيع» هي الحدّ الأعلى المتحفّظ. الربط بالذكاء الاصطناعي: سبب نجاح النماذج بأقلّ ممّا تتوقّعه النظرية.

مثال (32.2-8): تكلفة الثقة المعطيات: n يُرضي $\delta = 0.05$؛ نريد $\delta = 0.005$. المطلوب: الزيادة المطلوبة. الحل: الخطوة 1: δ يدخل لوغاريتمياً: $\ln(1/\delta)$ من 3.00 إلى 5.30. الخطوة 2: الزيادة في المقدار $2.3 \approx$ وحدة لوغاريتمية فقط. النتيجة: الثقة رخيصة، والدقّة غالية. الربط بالذكاء الاصطناعي: قاعدة ميزانية: استثمر في الدقّة لا في المزيد من الثقة.

مثال (32.2-9): مضاعفة الدقّة المعطيات: من $\varepsilon = 0.1$ إلى $\varepsilon = 0.05$. المطلوب: أثر ذلك في الحالتين. الحل: الخطوة 1: تحقّقي: $n \propto 1/\varepsilon$ الضعف. الخطوة 2: غير متحيّز: $n \propto 1/\varepsilon^2 \Rightarrow$ أربعة أضعاف. النتيجة: معدّل «التحقّقي» أسرع وهو «المعدّل السريع» الشهير. الربط بالذكاء الاصطناعي: تنظيف البيانات (لجعل المسألة تحقّقية) استثمار مضاعف الأثر.

مثال (32.2-10): لماذا δ لوغاريتمي؟ المعطيات: حدّ من الشكل $\sqrt{\frac{8}{n}\ln\frac{4\Pi}{\delta}}$. المطلوب: أثر δ. الحل: الخطوة 1: $\ln(4\Pi/\delta) = \ln(4\Pi) + \ln(1/\delta)$ — مجموع منفصل. الخطوة 2: كلّ division بـ 10 في δ يضيف $\ln 10 = 2.30$ فقط. النتيجة: من 10^{-2} إلى 10^{-6} يكلّف $9.2 \approx$ ناتاً. الربط بالذكاء الاصطناعي: ثقة 9999.99% ليست باهظة نظرياً!

مثال (32.2-11): PAC مقابل الاتساق المعطيات: خوارزمية متّسقة (الفصلان 30 و 31). المطلوب: هل هي PAC؟ الحل: الخطوة 1: الاتساق خاصية $n \to \infty$؛ و PAC يعطي معدّلاً. الخطوة 2: الاتساق لا يكفي: قد يتقارب ببطء شديد. النتيجة: PAC أقوى: ضمان بمعدّل عند كلّ n كبير بما يكفي. الربط بالذكاء الاصطناعي: اسأل «كم يكفي؟» لا «هل يتقارب؟».

مثال (32.2-12): تقرير دقّة بمعاملات معلومة المعطيات: 92% على 1000 عيّنة اختبار بثقة 95%. المطلوب: الصياغة السليمة. الحل: الخطوة 1: نضيف فترة الثقة من الفصل 30: $\pm 4.3\%$. الخطوة 2: «دقّة $92\% \pm 4.3\%$ بثقة 95%». النتيجة: رقم صادق وقابل للمقارنة. الربط بالذكاء الاصطناعي: معيار النشر السليم في تقارير النماذج.

مثال (32.2-13): الحافظ يفشل في PAC المعطيات: خوارزمية تحفظ التدريب وتخمّن عشوائيّاً خارجها. المطلوب: هل تتعلّم بـ PAC؟ الحل: الخطوة 1: خطأ التعميم $\approx \frac{1}{2}$ لكلّ n. الخطوة 2: لا يمكن أن يقلّ عن $\varepsilon < 1/2$. النتيجة: ليست متعلّمة بـ PAC لأيّ $\varepsilon < 1/2$. الربط بالذكاء الاصطناعي: معنى «التعلّم» يستبعد الحفظ الصريح.

مثال (32.2-14): فئة منتهية المعطيات: $|\mathcal{H}| = 1000$. المطلوب: تعقيد العيّنة من الفصل 30. الحل: الخطوة 1: نشترط $\varepsilon \le \sqrt{\frac{\ln(2|\mathcal{H}|/\delta)}{2n}}$. الخطوة 2: $n \ge \frac{\ln(2000/0.05)}{2(0.05)^2} = \frac{10.60}{0.005} = 2120$. النتيجة: نحو 2120 عيّنة لفضاء من ألف فرضية. الربط بالذكاء الاصطناعي: مرجع يُقاس عليه أداء الفضاءات غير المنتهية.

مثال (32.2-15): PAC للانحدار المعطيات: خسارة تربيعية وهدف $\mathbb{E}[(h-y)^2] \le \sigma^2 + \varepsilon$. المطلوب: الصياغة. الحل: الخطوة 1: ε بوحدات مربع الخطأ لا بوحدات الاحتمال. الخطوة 2: الضمان: $R(A(S)) \le \inf_{\mathcal{H}} R + \varepsilon$ باحتمال $\delta - 1$. النتيجة: الإطار يسري على أيّ خسارة محدودة أو مقيّدة. الربط بالذكاء الاصطناعي: مرونة الإطار سبب بقائه أربعين سنة.

أخطاء شائعة

- الخلط بين «دقّة 95%» و«ثقة 95%» (الأولى $\varepsilon - 1$ والثانية $\delta - 1$).
- تقييد الضمان على توزيع واحد ثمّ ادّعاء distribution-free.

- افتراض التحقّق في مسائل ملوّثة بالضجيج.
- نسيان أنّ δ احتمال فشل على **العيّنة** لا على نقطة.
- استخدام تعقيد عيّنة للفضاءات المنتهية على فضاءات غير منتهية.

المبرهنة (Blumer–Ehrenfeucht–Haussler–Warmuth / Vapnik–Chervonenkis): لتكن $\mathcal{H}$ فئة فرضيات. فإنّ

$$\text{قابلة للتعلّم بـ PAC (بخوارزمية } \mathcal{H}\text{ERM)} \quad \Longleftrightarrow \quad d_{\mathrm{VC}}(\mathcal{H}) < \infty \tag{3.32}$$

وفي الحالة التحقّقية، تعقيد العيّنة لـ ERM يحقّق

$$m_{\mathcal{H}}(\varepsilon, \delta) \;=\; O\!\left(\frac{d\,\ln(1/\varepsilon) + \ln(1/\delta)}{\varepsilon}\right) \tag{4.32}$$

$$\text{وبصريح العبارة:} \quad n \;\geq\; \frac{8\,d\,\ln(13/\varepsilon) + 4\ln(4/\delta)}{\varepsilon} \tag{5.32}$$

وفي الحالة غير المتحيّزة

$$m_{\mathcal{H}}(\varepsilon, \delta) \;=\; \Theta\!\left(\frac{d + \ln(1/\delta)}{\varepsilon^2}\right) \tag{6.32}$$

جدول الرموز

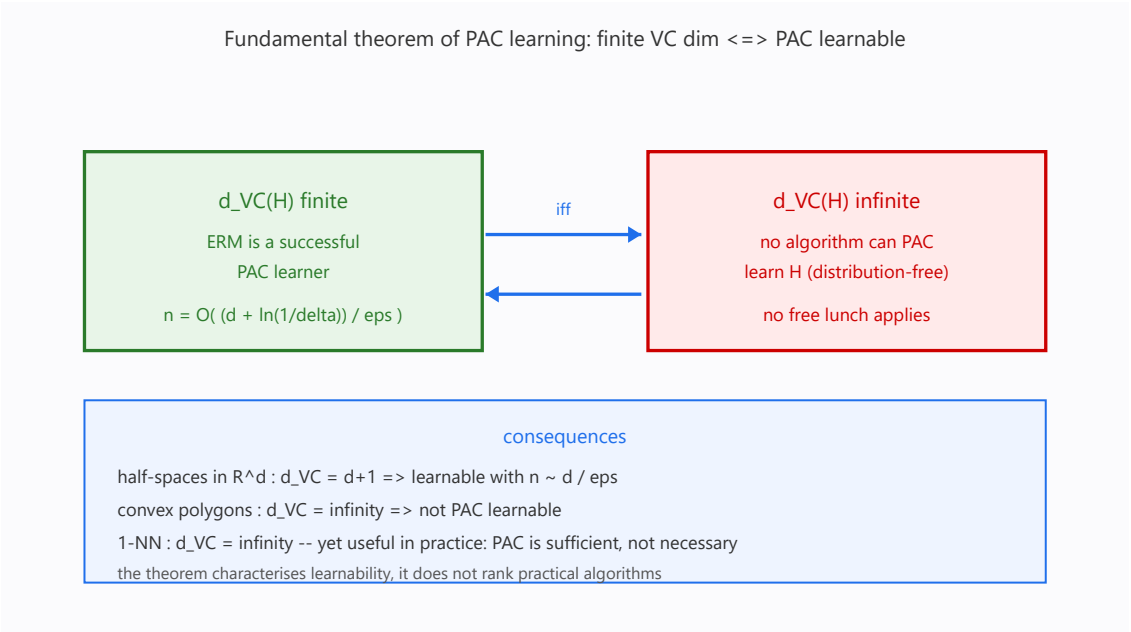
الرمز	المعنى	ملاحظة
d	بُعد VC	من الفصل 31
$1/\varepsilon$	معدّل «سريع» تحقّقي	نتيجة لانعدام خطأ التدريب
$1/\varepsilon^2$	معدّل غير متحيّز	بسبب تباين التقدير
$\ln(1/\varepsilon)$	عامل إضافي تحقّقي	ثمن البحث في $\mathcal{H}$
ERM	الخوارزمية الكافية	لا حاجة لخوارزمية أعقد
$\Leftrightarrow$	تصنيف تامّ	ضرورة وكفاية

الرسم

<figure> الشكل 2.32: بُعد VC المنتهي يكفي ويَلزم لقابلية التعلّم بـ PAC، وخوارزمية ERM تحقّق الحدّ. </figcaption></figure>

البرهان

الخطوة 1 (الكفاية): من مبرهنة التأسيس (5.31): باحتمال $1-\delta$ ولكلّ h: $R(h) \leq \hat{R}(h) + \sqrt{\frac{8}{n}\ln\frac{4\Pi(2n)}{\delta}}$. وفي الحالة التحقّقية $\hat{R}(\hat{h}) = 0$. وبحلّ المتراجحة $\sqrt{\frac{8}{n}\ln\frac{4\Pi(2n)}{\delta}} \leq \varepsilon$ مع $\Pi(2n) \leq (2en/d)^d$ نحصل على (4.32)–(5.32) بعد جبر قياسي. $\blacksquare$



شكل ٢٠٣٢: *
مبرهنة التأسيس لـ PAC

الخطوة 2 (الضرورة — مخطّط): لو كان $d_{\mathrm{VC}} = \infty$، فلكلّ n توجد مجموعة من $2n$ نقطة محطومة. نبني توزيعاً مركّزاً على هذه النقاط مع وسوم عشوائية مستقلّة؛ فأيّ خوارزمية ترى نصف النقاط فقط، وبالاستقلال يبقى خطؤها المتوقّع على النصف الآخر $\approx \frac{1}{2} \Rightarrow$ لا يمكن ضمان $\varepsilon < \frac{1}{4}$ لأيّ $n \Rightarrow$ غير قابلة للتعلّم. ■

الخطوة 3 (غير المتحيّز): هنا لا ينعدم $\hat{R}(\hat{h})$، بل يقترب من $\inf_{\mathcal{H}} R$ بمعدّل التركيز $\sqrt{d/n} \Rightarrow$ بحلّ $\sqrt{\frac{Cd + C\ln(1/\delta)}{n}} \le \varepsilon$ نحصل على $n \propto 1/\varepsilon^2$، وهو (6.32). ■

الخطوة 4 (لماذا ERM تكفي؟): لأنّ الحدود «لكلّ h معاً»، فلا حاجة لخوارزمية تبحث بذكاء أكبر من حيث المعدّل (وقد تفيد في الثوابت وفي الحساب). ■

خمسة عشر مثالاً محلولاً

مثال (1-3.32): المقياس لفضاء بُعده 10 المعطيات: $d = 10$، $\varepsilon = 0.1$، $\delta = 0.05$ تحقّقي. المطلوب: n بالمقياس (4.32). الحل: الخطوة 1: $\ln 10 = 2.303$؛ $\ln(1/\varepsilon) = 3.00$. الخطوة 2: $(10(2.303) + 3.00)/0.1 = (23.03 + 3.00)/0.1 = 260$. النتيجة: نحو 260 عيّنة بالمقياس. الربط بالذكاء الاصطناعي: رقم «مقياسي» يفيد التخطيط لا الضمان.

مثال (2-3.32): الحدّ الصريح نفسه المعطيات: نفس المعاملات بـ (5.32). المطلوب: n. الحل: الخطوة 1: $\ln 130 = 4.868 \Rightarrow \ln(13/0.1) = 4.868$. الخطوة 2: $8(10)(4.868) = 389.4 \Rightarrow 4\ln(80) = 17.53$ المجموع 406.9. الخطوة 3: $4069/0.1 = 406.9 \le n$. النتيجة: الحدّ الصريح أكبر من المقياس بـ 6.15 مرّة. الربط بالذكاء الاصطناعي: فرق شائع بين «الرتبة» و«الرقم القابل للاستخدام».

مثال (3-3.32): الحالة غير المتحيّزة المعطيات: $d = 10$، $\varepsilon = 0.1$، $\delta = 0.05$ غير متحيّز. المطلوب: n بالمقياس (6.32). الحل: الخطوة 1: $13/0.01 = 1300 = (10 + 3.00)/(0.1)^2$. النتيجة: خمسة أضعاف الحالة التحقّقية عند هذا ε. الربط بالذكاء الاصطناعي: «البيانات النظيفة» مكسب يعادل مضاعفة العيّنة.

مثال (4-3.32): مضاعفة الدقّة في الحالتين المعطيات: من $\varepsilon = 0.1$ إلى $\varepsilon = 0.05$ بـ $d = 10$. المطلوب:

المعاملان. الحل: الخطوة 1: تحقّقي: $n \propto 1/\varepsilon \Rightarrow$ معامل 2. الخطوة 2: غير متحيّز: $n \propto 1/\varepsilon^2 \Rightarrow$ معامل 4. النتيجة: الفرق بين المعدّلين يتّسع مع تشديد الدقّة. الربط بالذكاء الاصطناعي: كلّما طلبت دقّة أعلى، زادت قيمة تنظيف البيانات.

مثال (3.32-5): تكلفة الثقة في PAC المعطيات: $d = 10$، $\varepsilon = 0.1$، δ من 0.05 إلى 0.001. المطلوب: التغيّر بالمقياس. الحل: الخطوة 1: $\ln(1/\delta)$ من 3.00 إلى 6.91 $\Rightarrow$ 3.91+. الخطوة 2: المقدار من 26.03 إلى 29.94 $\Rightarrow$ n من 260 إلى 299 (بالمقياس). النتيجة: +15% فقط مقابل تشديد الثقة 50 ضعفاً. الربط بالذكاء الاصطناعي: الثقة رخواصة في كلّ حدود التعلّم تقريباً.

مثال (3.32-6): نموّ التعقيد مع البعد المعطيات: d من 10 إلى 1000 تحقّقي بـ $\varepsilon = 0.05$. المطلوب: n في الحالتين. الحل: الخطوة 1: $d = 10$: $(10(3.00) + 3)/0.05 = 660$. الخطوة 2: $d = 1000$: $(3000 + 3)/0.05 = 60060$. النتيجة: مئة ضعف السعة $\Rightarrow$ مئة ضعف البيانات (خطّي تماماً). الربط بالذكاء الاصطناعي: العلاقة الخطّية هي أهمّ نتيجة عملية في هذا الفصل.

مثال (3.32-7): سعة لانهائية $\Rightarrow$ غير قابل للتعلّم المعطيات: المضلّعات المحدّبة في $\mathbb{R}^2$ ($d_{\text{VC}} = \infty$). المطلوب: هل هي قابلة للتعلّم بـ PAC؟ الحل: الخطوة 1: بـ (3.32): لا. الخطوة 2: لأيّ n يمكن بناء توزيع يفشل عليه كلّ متعلّم. النتيجة: لا توجد خوارزمية — مهما بلغت قوّتها — تعلّمها distribution-free. الربط بالذكاء الاصطناعي: حدود قابلة للإثبات على «ما لا يمكن تعلّمه».

مثال (3.32-8): فضاء منتهٍ بـ $|\mathcal{H}| = 2^{20}$ المعطيات: $d \leq 20$. المطلوب: n تحقّقي بـ $\varepsilon = 0.05$، $\delta = 0.05$. الحل: الخطوة 1: $(20(3.00) + 3)/0.05 = 1260$. النتيجة: مليون فرضية تتعلّم بـ 1260 عيّنة (بالمقياس). الربط بالذكاء الاصطناعي: السعة لوغاريتمية في عدد الفرضيات — درس الفصل 31 مجدّداً.

مثال (3.32-9): العتبات على الخطّ الحقيقي المعطيات: $d = 1$، $\varepsilon = 0.05$، $\delta = 0.05$. المطلوب: n. الحل: الخطوة 1: $(1(3.00) + 3)/0.05 = 120$. النتيجة: 120 عيّنة لتعلّم عتبة واحدة بدقّة 95%. الربط بالذكاء الاصطناعي: أصغر مسألة تعلّم مفيدة — ومناسبة للتدريس.

مثال (3.32-10): نصف فضاءات في $\mathbb{R}^{100}$ المعطيات: $d = 101$، $\varepsilon = 0.05$. المطلوب: n. الحل: الخطوة 1: $(101(3.00) + 3)/0.05 = 6120$. النتيجة: ستّة آلاف عيّنة لمصنّف خطّي بمئة خصيصة. الربط بالذكاء الاصطناعي: قاعدة الإبهام «20–60 عيّنة لكلّ بُعد» في الممارسة أقرب ممّا تبدو.

مثال (3.32-11): شجرة قرار بـ 32 ورقة المعطيات: $d_{\text{VC}} \approx 138$ (من 4.31-10)، $\varepsilon = 0.05$. المطلوب: n. الحل: الخطوة 1: $(138(3.00)+3)/0.05 = 8340$. النتيجة: نحو ثمانية آلاف عيّنة. الربط بالذكاء الاصطناعي: حساب مباشر يبرّر تقليم الأشجار عند قلّة البيانات.

مثال (3.32-12): شبكة عصبية المعطيات: $W = 10^6$ و $L = 10 \Rightarrow d \approx 1.38 \times 10^8$، $\varepsilon = 0.05$. المطلوب: n. الحل: الخطوة 1: $(1.38 \times 10^8(3.00) + 3)/0.05 \approx 8.3 \times 10^9$. النتيجة: نحو ثمانية مليارات عيّنة! الربط بالذكاء الاصطناعي: الشبكات تعمل ببيانات أقلّ بمراتب $\Rightarrow$ المبرهنة لا تفسّرها (الفصل 34).

مثال (3.32-13): قابلية التعلّم خصيصة للفئة المعطيات: فئتان بنفس عدد المعلمات وأبعاد VC مختلفة. المطلوب: أيّهما أسهل تعلّماً؟ الحل: الخطوة 1: بـ (4.32) الأسهل هي ذات d_{VC} الأصغر. الخطوة 2: عدد المعلمات لا يظهر في الحدّ إطلاقاً. النتيجة: «قابلية التعلّم» خصيصة تركيبية لا عددية. الربط بالذكاء الاصطناعي: إعادة صياغة لدرس الفصل 31 بلغة PAC.

مثال (3.32-14): هل يفيد التعلّم غير الصحيح؟ المعطيات: نسمح للخوارزمية بالخروج من $\mathcal{H}$. المطلوب: هل يتحسّن المعدّل من حيث d؟ الحل: الخطوة 1: حدود الضرورة في (3.32) تسري على **كلّ** الخوارزميات. الخطوة 2: إذن لا يمكن تجاوز معدّل d/ε بالخروج من $\mathcal{H}$. النتيجة: التعلّم غير الصحيح يفيد **حسابيّاً** لا إحصائيّاً. الربط بالذكاء الاصطناعي:

تمييز دقيق بين نوعَي الصعوبة (سيظهر في 8.32).

مثال (15-3.32): ماذا نستفيد عملياً من المبرهنة؟ المعطيات: مشروع جديد. المطلوب: القاعدة العملية. الحل: الخطوة 1: احسب (أو قدّر) d_{VC} لنموذجك. الخطوة 2: خطّط حجم البيانات: $n \approx 20\,d$ إلى $60\,d$ لكلّ وحدة من $1/\varepsilon$. الخطوة 3: إن لم يتوفّر ذلك، قلّل السعة (تنظيم، تمثيل أفضل، تدريب مسبق). النتيجة: إطار قرار كمّي لتخصيص الموارد. الربط بالذكاء الاصطناعي: هذه هي القيمة العملية الوحيدة المستخلصة من كلّ هذا الجزء.

أخطاء شائعة

- استخدام معدّل $1/\varepsilon^2$ في الحالة التحقّقية (الأصح $1/\varepsilon$).
- اعتبار (5.32) «الرقم المطلوب فعلاً» (هو حدّ أعلاه فضفاض).
- تطبيق المبرهنة على فئات سعتها لانهائية بلا تعديل (هامش/تنظيم).
- الظنّ أنّ خوارزمية أذكى من ERM تحسّن **المعدّل** (لا تفعل عادةً).
- نسيان أنّ المبرهنة distribution-free (الأسوأ).

المبرهنة: في الحالة غير المتحيّزة، خوارزمية ERM تحقّق باحتمال $\geq 1-\delta$:

$$R(\hat{h}) \;\leq\; \inf_{h\in\mathcal{H}} R(h) \;+\; \varepsilon, \qquad n \;\geq\; \frac{C\big(d+\ln(1/\delta)\big)}{\varepsilon^2} \tag{7.32}$$

$$n \;\geq\; \frac{8}{\varepsilon^2}\Big(2d+\ln\frac{4}{\delta}\Big) \quad \text{وبصريح العبارة (من مبرهنة التأسيس):} \tag{8.32}$$

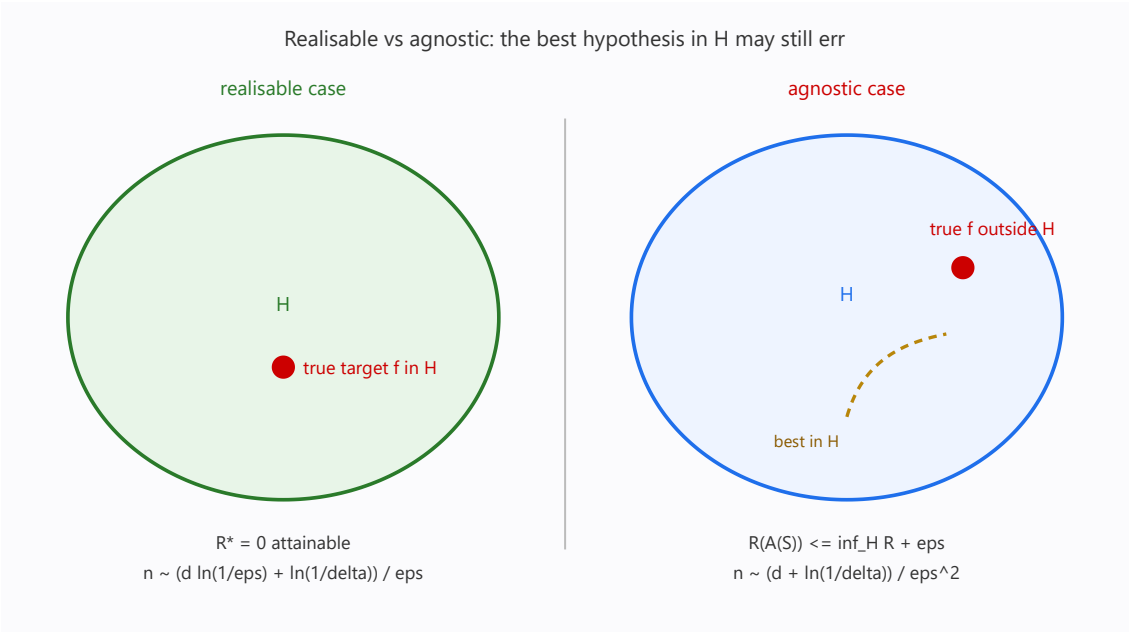
ولا توجد خوارزمية — صحيحة كانت أو غير صحيحة — تحقّق معدّلاً أفضل من حيث d و ε في أسوأ الحالات.

جدول الرموز

الرمز	المعنى	ملاحظة
$\inf_{\mathcal{H}} R$	أفضل ما يمكن لـ $\mathcal{H}$	قد يكون > 0
ε	الفجوة فوق الأفضل الممكن	لا فوق الصفر
خطأ التقريب	$\inf_{\mathcal{H}} R - R^{\star}$	من الفصل 30
خطأ التقدير	ما تقلّله العيّنة	المقدار الذي يحكمه (7.32)
$1/\varepsilon^2$	معدّل التركيز	أبطأ من التحقّقي
أسوأ الحالات	الحدّ السفلي يطابق	لا مجال للتحسين

الرسم

<figure> الشكل<figcaption> 3.32: في الحالة التحقّقية تقترب من الصفر بمعدّل $1/\varepsilon$؛ وفي غير المتحيّزة تقترب من أفضل ما في $\mathcal{H}$ بمعدّل $1/\varepsilon^2$</figcaption>. </figure>



شكل ٣٢.٣٢: *
التعلم غير المتحيز

البرهان (مخطّط)

الخطوة 1: في الحالة غير المتحيّزة: $R(\hat{h}) \le \hat{R}(\hat{h}) + \sup|R - \hat{R}|$ و $\hat{R}(\hat{h}) \le \hat{R}(h^\star_{\mathcal{H}})$ و $\mathbb{E}[\hat{R}(h^\star)] = R(h^\star) = \inf_{\mathcal{H}} R$.

الخطوة 2: بالتحكّم في $\sup|R - \hat{R}| \le \varepsilon/2$ بمبرهنة التأسيس (5.31) وتركيز الفرق حول متوقّعه، نحتاج $\frac{8}{n}\ln\frac{4\Pi(2n)}{\delta} \le \frac{\varepsilon^2}{4} \Rightarrow$ بحلّها مع Sauer نحصل على (8.32). ■

الخطوة 3 (الحدّ السفلي): بناء توزيع تتصرّف فيه كلّ الفرضيات تقريباً كرمي عملة، نجد أنّ التمييز بين «أفضل من $\inf + \varepsilon$» و«أسوأ منه» يتطلّب $\Omega(d/\varepsilon^2)$ عيّنة (حدّ سفلي بالاستعلامات الإحصائية/Fano). ■

خمسة عشر مثالاً محلولاً

مثال (8.32-1): قياس الفجوة الصحيحة المعطيات: $R^\star = 0.08$ (ضجيج)، $\inf_{\mathcal{H}} R = 0.15$، $\varepsilon = 0.05$. المطلوب: ما يضمنه (7.32). الحل: الخطوة 1: الضمان $R(\hat{h}) \le 0.15 + 0.05 = 0.20$. الخطوة 2: ولا ضمان على الـ 0.08 (خطأ التقريب 0.07 لا يُقلَّل بالبيانات). النتيجة: التعلّم غير المتحيّز يضمن «الأفضل في الفئة + ϵ» فقط. الربط بالذكاء الاصطناعي: لا تطالب النموذج بما لا تسمح به فئته.

مثال (8.32-2): تعقيد العيّنة غير المتحيّز المعطيات: $d = 10$، $\varepsilon = 0.1$، $\delta = 0.05$. المطلوب: n بـ (8.32). الحل: الخطوة 1: $2d + \ln(4/0.05) = 20 + 4.382 = 24.382$. الخطوة 2: $n \ge 8(24.382)/(0.01) = 19{,}506$. النتيجة: نحو 19,500 عيّنة. الربط بالذكاء الاصطناعي: الحدود الصريحة غير المتحيّزة باهظة — خطّط بالمقياس.

مثال (8.32-3): أرضية الضجيج المعطيات: 10% من الوسوم مقلوبة، الحقيقة حتمية. المطلوب: أفضل أداء ممكن. الحل: الخطوة 1: $R^\star \ge 0.10$. الخطوة 2: مهما كبرت العيّنة لا ينزل الخطأ عن 10%. النتيجة: أرضية لا تُكسر $\Rightarrow$ «غير متحيّز» هو الوصف الصحيح. الربط بالذكاء الاصطناعي: تنظيف الوسوم قبل تكبير النموذج.

مثال (8.32-4): ضجيج في التسمية الطبية المعطيات: اتّفاق الأطباء 92%. المطلوب: سقف أداء النموذج. الحل: الخطوة 1: $R^\star \approx 0.08$ على الأقل. الخطوة 2: ادّعاء دقّة 98% ادّعاء حفظ للضجيج. النتيجة: مقارنة النموذج بالخبراء لا

بالكمال. الربط بالذكاء الاصطناعي: سبب استخدام «اتّفاق بين الموسمين» معياراً.

مثال (32.4-5): سوء تحديد النموذج المعطيات: علاقة تربيعية ونموذج خطّي. المطلوب: التوصيف. الحل: الخطوة 1: $\inf_{\mathcal{H}} R > R^\star \Rightarrow$ خطأ تقريب موجب. الخطوة 2: الحالة غير المتحيّزة بالتعريف (الحقيقة خارج $\mathcal{H}$). النتيجة: كلّ سوء تحديد يجعل المسألة غير متحيّزة. الربط بالذكاء الاصطناعي: التشخيص من الفصل 30 بلغة PAC.

مثال (32.4-6): تفكيك الخطأ مرّتين المعطيات: $R(\hat{h}) = 0.22$، $\inf_{\mathcal{H}} R = 0.15$، $R^\star = 0.08$. المطلوب: التقريب والتقدير. الحل: الخطوة 1: التقريب $0.07 = 0.08 - 0.15 =$. الخطوة 2: التقدير $0.07 = 0.15 - 0.22 =$. النتيجة: مناصفة $\Rightarrow$ زد البيانات و حسّن الفئة معاً. الربط بالذكاء الاصطناعي: خريطة تشخيص من الفصل 30 مطابقة.

مثال (32.4-7): الفرق بين المعدّلين بالأرقام المعطيات: $d = 10$، $\varepsilon = 0.01$. المطلوب: n في الحالتين بالمقياس. الحل: الخطوة 1: تحقّقي: $10(4.605)(3)/0.01 = 4905$. الخطوة 2: غير متحيّز: $(10+3)/10^{-4} = 130{,}000$. الخطوة 3: النسبة $26.5\times$. النتيجة: عند الدقّة العالية يتّسع الفرق كثيراً. الربط بالذكاء الاصطناعي: قيمة البيانات النظيفة تتضاعف مع طموح الدقّة.

مثال (32.4-8): تشخيص واقعي المعطيات: تصنيف أمراض نادرة بـ $d = 50$، نريد $\varepsilon = 0.02$ غير متحيّز. المطلوب: n. الحل: الخطوة 1: بالمقياس: $(50+3)/(4\times 10^{-4}) = 132{,}500$. الخطوة 2: بالصريح: $8(100+4.38)/(4\times 10^{-4}) = 2{,}087{,}600$. النتيجة: بين 132 ألفاً ومليونَي عيّنة. الربط بالذكاء الاصطناعي: الطموحات الطبية تحتاج تعاوناً مؤسّسياً لجمع البيانات.

مثال (32.4-9): خسارة مرجّحة غير متحيّزة المعطيات: تكلفة FN عشرة أضعاف FP. المطلوب: هل يتغيّر الإطار؟ الحل: الخطوة 1: الخسارة محدودة (بعد إعادة القياس) $\Rightarrow$ الإطار يسري. الخطوة 2: يتغيّر $\inf_{\mathcal{H}} R$ ولا يتغيّر المعدّل. النتيجة: المرونة ميزة الإطار لا قيده. الربط بالذكاء الاصطناعي: إعادة وزن الخسارة لا تُفسد الضمان النظري.

مثال (32.4-10): هل خوارزمية أذكى أفضل؟ المعطيات: ERM مقابل خوارزمية «مبتكَرة». المطلوب: هل يمكنها تجاوز (32.7)؟ الحل: الخطوة 1: الحدّ السفلي يسري على كلّ الخوارزميات. الخطوة 2: التحسين الممكن في الثوابت والاعتماد على البيانات لا في الرتبة. النتيجة: ابحث عن حدود معتمدة على البيانات لا عن «خوارزمية سحرية». الربط بالذكاء الاصطناعي: تمييز مهمّ في تقييم الأبحاث الجديدة.

مثال (32.4-11): دقّة عالية غير متحيّزة المعطيات: $d = 10$، نريد $\varepsilon = 0.01$. المطلوب: n. الحل: الخطوة 1: بالمقياس $(10+3)/10^{-4} = 130{,}000$. الخطوة 2: مقابل 260 عند $\varepsilon = 0.1$ تحقّقي — فرق 500 ضعف! النتيجة: الدقّة العالية مع الضجيج أغلى ما يمكن طلبه. الربط بالذكاء الاصطناعي: قاعدة الميزانية الأهمّ في تصميم أنظمة التعلّم.

مثال (32.4-12): التحقّقي عند دقّة عالية المعطيات: بيانات نظيفة، $d = 10$، $\varepsilon = 0.01$. المطلوب: n. الحل: الخطوة 1: $10(4.605)(3)/0.01 = 4905$. النتيجة: أقلّ بـ 26 مرّة من الحالة غير المتحيّزة. الربط بالذكاء الاصطناعي: البيانات النظيفة «تشتري» معدّلاً أسرع.

مثال (32.4-13): كيف نختبر التحقّقيّة؟ المعطيات: نموذج بلغ خطأ تدريب 0.001 بنهاية التدريب. المطلوب: هل المسألة تحقّقية؟ الحل: الخطوة 1: خطأ تدريب شبه معدوم دليل على (شبه) التحقّق. الخطوة 2: لكن احذر: قد يكون حفظاً (خطأ اختبار مرتفع). النتيجة: الاختبار الحاسم هو فجوة التعميم لا خطأ التدريب. الربط بالذكاء الاصطناعي: تشخيص مجّاني من منحنيات التدريب.

مثال (32.4-14): الصلة بتعقيد Rademacher المعطيات: حدّ Rademacher من الفصل 31. المطلوب: هل يعطي معدّلاً أفضل؟ الحل: الخطوة 1: الحدّ $2\widehat{\mathfrak{R}}_S$ يعطي $\sqrt{d/n}$ أي $n \propto d/\varepsilon^2$ — نفس معدّل (32.7). الخطوة 2: ميزته أنّه معتمد على البيانات (أرقام أصغر فعليّاً). النتيجة: نفس الرتبة، ثوابت أفضل. الربط بالذكاء الاصطناعي: تكامل الأدوات لا تنافسها.

مثال (4.32-15): خلاصة القرار المعطيات: مسألة واقعية ملوّثة. المطلوب: الترتيب الصحيح للخطوات. الحل: الخطوة 1: قدّر $R^\star$ من اتّفاق الخبراء أو تكرار الوسم. الخطوة 2: اختر $\mathcal{H}$ يخفض خطأ التقريب (تحيز). الخطوة 3: اجمع عيّنة بحجم $n \propto d/\varepsilon^2$ لتخفيض خطأ التقدير. الخطوة 4: راقب الفجوة بين التدريب والتحقّق للتشخيص. النتيجة: خطة عمل كاملة مستمدّة من النظرية. الربط بالذكاء الاصطناعي: هذا هو «الخلاصة القابلة للتنفيذ» من نظرية PAC.

أخطاء شائعة

- مقارنة الأداء بـ $R^\star$ بدل $\inf_{\mathcal{H}} R$ (الضمان لا يغطّي التقريب).
- توقّع معدّل $1/\varepsilon$ في مسائل ملوّثة.
- اعتبار خطأ التقريب «خطأ تقدير» ومعالجته ببيانات إضافية.
- نسيان أنّ الحدّ السفلي يمنع أيّ خوارزمية من التفوّق في أسوأ الحالات.
- الخلط بين «غير متحيّز» و«غير متحيّز للوسوم» (الأخير نوع من الضجيج).

المبرهنة: لكلّ فئة $\mathcal{H}$ بُعد $d_{\mathrm{VC}} \geq 2$ ولكلّ خوارزمية تعلّم (صحيحة أو غير صحيحة)، في الحالة التحقّقية ولكلّ $\varepsilon \leq \frac{1}{8}$ و $\delta \leq \frac{1}{4}$:

$$m_{\mathcal{H}}(\varepsilon, \delta) \;\geq\; \frac{d-1}{32\,\varepsilon} \tag{9.32}$$

وفي الحالة غير المتحيّزة

$$m_{\mathcal{H}}(\varepsilon, \delta) \;=\; \Omega\!\left(\frac{d}{\varepsilon^2}\right) \tag{10.32}$$

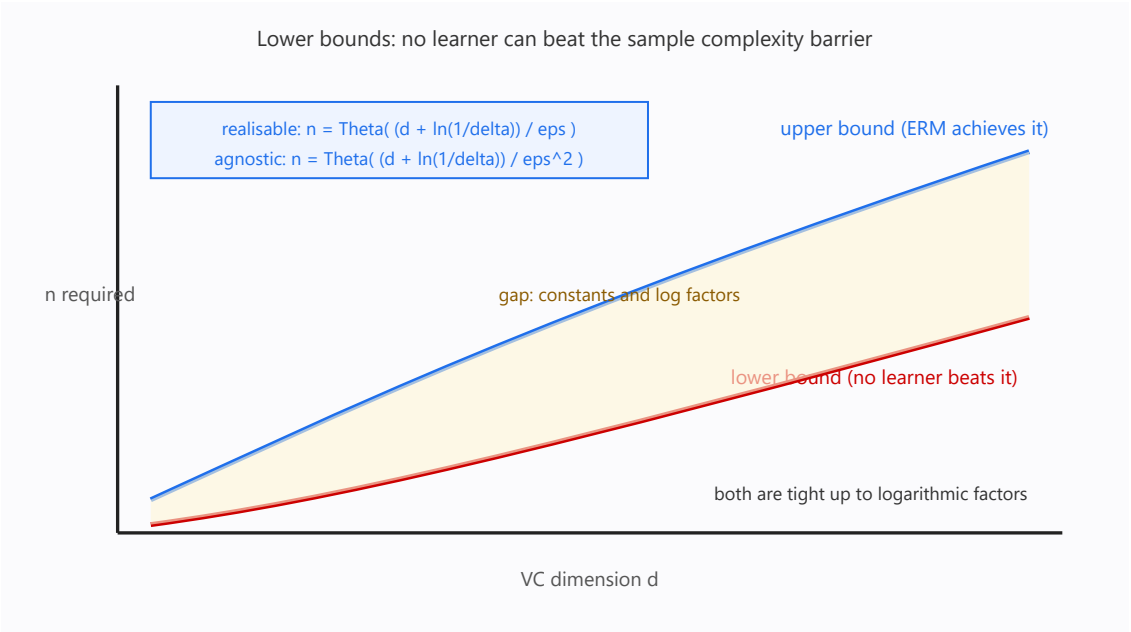
أي أنّ معدّلَي (4.32) و (6.32) **مثاليّان من حيث الرتبة**: لا خوارزمية أسرع.

جدول الرموز

الرمز	المعنى	ملاحظة
حدّ سفلي	ما لا يمكن تجاوزه	«حاجز لا خوارزمي»
$d-1$	يظهر بدل d	تفصيل تقني في البرهان
$\frac{1}{32}$	ثابت الحدّ	متحفّظ جداً
$\Omega(\cdot)$	رتبة سفلية	تطابق الرتبة العلوية
لا يوجد مجّان	كلّ تحسين له ثمن	رسالة الفصل
استعلامات/Fano	أدوات الإثبات	صلة بالفصل 27

الرسم

<figure> الشكل<figcaption> 4.32: الحدّ العلوي (ما تحقّقه ERM والحدّ السفلي (ما لا تستطيع أيّ خوارزمية تجاوزه) يتطابقان في الرتبة، والفجوة في الثوابت واللوغاريتمات.</figcaption> </figure>



شكل ٤.٣٢: *
الحدود السفلى لتعقيد العينة

البرهان (مخطّط)

الخطوة 1 (بناء التوزيع السيّئ): نختار d نقطة محطومة ونوزّع عليها توزيعاً، ونأخذ الوسوم عشوائيّةً مستقلّة باحتمال $\frac{1}{2}$ (أو نخفي واحدة ونجعلها «السرّ»).

الخطوة 2 (حجّة المعلومة): أيّ خوارزمية ترى n عيّنة، وكلّ نقطة غير مشاهدة تحمل بتّاً من المعلومة غير المعروفة. لجعل الخطأ $< \varepsilon$ يجب أن «تخمن» معظم النقاط غير المشاهدة صحيحاً، وهذا يتطلّب عدداً كافياً من المشاهدات.

الخطوة 3 (الاستقلال): بحساب الاحتمال، الخطأ المتوقّع على الجزء غير المشاهد $\geq \frac{1}{2} \times$ نسبة غير المشاهد، وبجعل نسبة غير المشاهد $\approx \frac{d}{2n}$ نحتاج $\frac{d}{2n} \cdot \frac{1}{2} \leq \varepsilon \Rightarrow n \geq \frac{d}{4\varepsilon}$، وبالثوابت الدقيقة في المراجع يصير $\frac{d-1}{32\varepsilon}$. ■

الخطوة 4 (غير المتحيّز): بحجّة مشابهة مع ضجيج يجعل كلّ فرضية «قريبة من رمي عملة»، نحتاج التمييز بين فروق من رتبة ε في المتوسطات $\Rightarrow \Omega(d/\varepsilon^2)$ بتركيز الانحراف المعياري $\sqrt{d/n}$. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.32): حدّ سفلي لفضاء بُعده ألف المعطيات: $d = 1000$، $\varepsilon = 0.01$. المطلوب: الحدّ السفلي بـ (9.32). الحل: الخطوة 1: $\frac{999}{0.32} = 3122$. $\frac{999}{32(0.01)}$. النتيجة: لا خوارزمية تتعلّم بأقلّ من 3122 عيّنة. الربط بالذكاء الاصطناعي: رقم يمكن استخدامه في مراجعة ادّعاءات «نتعلّم من 100 عيّنة».

مثال (2-5.32): فجوة الحدّين المعطيات: $d = 10$، $\varepsilon = 0.1$. المطلوب: الحدّان العلوي والسفلي. الحل: الخطوة 1: علوي بالمقياس: 260. الخطوة 2: سفلي: $\frac{9}{3.2} = 2.81 \Rightarrow 3$ عيّنات. الخطوة 3: الفجوة $87 \approx$ ضعفاً. النتيجة: الحدود السفلية ضعيفة جدّاً بالثوابت. الربط بالذكاء الاصطناعي: قيمتها في **الرتبة** لا في الرقم.

مثال (3-5.32): حدّ سفلي غير متحيّز المعطيات: $d = 100$، $\varepsilon = 0.05$. المطلوب: الرتبة السفلية. الحل: الخطوة 1: $n = \Omega(100/0.0025) = \Omega(4 \times 10^4)$. النتيجة: نحو أربعين ألف عيّنة على الأقل. الربط بالذكاء الاصطناعي: الحدّ السفلي هنا أقرب للواقع من الحالة التحقّقية.

مثال (32.5-4): لماذا نهتمّ بالحدود السفلية؟ المعطيات: فريق يدّعي خوارزمية «تتعلّم من عيّنات قليلة». المطلوب: كيف نتحقّق؟ الحل: الخطوة 1: نحسب الحدّ السفلي لفئته. الخطوة 2: إن كان ادّعاؤه أدنى منه ⇒ إمّا الفئة أصغر أو الضمان أضعف أو التوزيع خاصّ. النتيجة: أداة تدقيق علمي قبل أيّ شيء آخر. الربط بالذكاء الاصطناعي: حماية من المبالغات التسويقية في «قليل البيانات».

مثال (32.5-5): حدّ سفلي للعتبات المعطيات: $d = 1$، $\varepsilon = 0.05$. المطلوب: الحدّ السفلي. الحل: الخطوة 1: $\frac{1-1}{32\varepsilon} = 0 \Rightarrow$ الحدّ (32.9) لا يفيد عند $d = 1$. الخطوة 2: تُستخدم حدود خاصّة: $n = \Omega(1/\varepsilon)$ للعتبات. النتيجة: الحدود العامّة لا تكفي للحالات الصغيرة. الربط بالذكاء الاصطناعي: استخدم الحدود الخاصّة بالفئة متى وُجدت.

مثال (32.5-6): حدود تعتمد على العيّنة (instance-dependent) المعطيات: بيانات قابلة للفصل بهامش كبير. المطلوب: هل ينطبق الحدّ السفلي؟ الحل: الخطوة 1: الحدّ السفلي أسوأ الحالات (على كلّ التوزيعات). الخطوة 2: توزيعك الميّال للهامش الكبير أسهل ⇒ الحاجة الفعلية أقلّ. النتيجة: الحدود السفلية لا تمنع الاستفادة من بنية البيانات. الربط بالذكاء الاصطناعي: مبرّر نظري لنجاح النماذج بأقلّ من المتوقّع.

مثال (32.5-7): تطابق الرتبة المعطيات: تحقّقي بـ d كبير. المطلوب: هل التحسين ممكن؟ الحل: الخطوة 1: العلوي $O(d/\varepsilon)$ والسفلي $\Omega(d/\varepsilon) \Rightarrow$ تطابق في d و ε. الخطوة 2: الباقي: ثوابت وعامل $\ln(1/\varepsilon)$. النتيجة: نظرية التعلّم «مكتملة» من حيث الرتبة لهذه المسألة. الربط بالذكاء الاصطناعي: حالة نادرة من الاكتمال النظري في تعلّم الآلة.

مثال (32.5-8): أين تبقى الفجوة؟ المعطيات: العلوي يحتوي $\ln(1/\varepsilon)$ والسفلي لا يحتويه. المطلوب: التفسير. الحل: الخطوة 1: عامل $\ln(1/\varepsilon)$ ناتج عن «البحث في الفضاء». الخطوة 2: هل هو ضروري؟ نعم في أسوأ الحالات (معروف في الأدبيات). النتيجة: الفجوة اللوغاريتمية مفهومة ومثبتة. الربط بالذكاء الاصطناعي: الفجوات المتبقية ليست «عجزاً» بل «حقائق رياضية».

مثال (32.5-9): هل يفيد التعلّم النشط؟ المعطيات: الخوارزمية تختار العيّنات التي تريد وسومها. المطلوب: هل يتجاوز الحدّ السفلي؟ الحل: الخطوة 1: في أسوأ الحالات لا يتجاوز الرتبة. الخطوة 2: في حالات عمليّة (هامش كبير، عدم يقين مركّز) يحقّق تحسناً كبيراً. النتيجة: التعلّم النشط يفيد **عملياً** لا في أسوأ الحالات. الربط بالذكاء الاصطناعي: تبرير الاستثمار في وسمٍ انتقائي للبيانات الطبية.

مثال (32.5-10): حدّ سفلي معلوماتي (فانو) المعطيات: مبرهنة فانو من الفصل 27. المطلوب: الصلة. الحل: الخطوة 1: فانو: $P_e \geq 1 - \frac{I(M;S)+1}{\ln|\mathcal{M}|}$. الخطوة 2: بجعل $\mathcal{M}$ = الوسوم الممكنة على d نقطة: $\ln|\mathcal{M}| = d$. الخطوة 3: المعلومة المكتسبة من n عيّنة محدودة بـ $n \Rightarrow$ نصل إلى حدّ سفلي من نفس الرتبة. النتيجة: الحدود السفلية للتعلّم حدود معلوماتية في جوهرها. الربط بالذكاء الاصطناعي: وحدة المادة: الجزء الخامس يخدم هذا الجزء.

مثال (32.5-11): جدول الحدود المتطابقة المعطيات: الحالتان. المطلوب: الخلاصة. الحل: الخطوة 1: تحقّقي: $n = \tilde{\Theta}(d/\varepsilon)$. الخطوة 2: غير متحيّز: $n = \Theta(d/\varepsilon^2)$. النتيجة: الرتبتان مغلقتان (up to logs). الربط بالذكاء الاصطناعي: جدول يُحفظ ويُستخدم في التخطيط.

مثال (32.5-12): ميزانية جمع البيانات المعطيات: $d = 500$، نريد $\varepsilon = 0.02$ غير متحيّز. المطلوب: الحدّان. الحل: الخطوة 1: سفلي: $\Omega(1.25 \times 10^6) = \Omega(500/4 \times 10^{-4})$. الخطوة 2: علوي بالمقياس: $(500 + 3)/4 \times 10^6 = 1.26 \times 10^{-4}$. النتيجة: الحدّان متقاربان بشكل مذهل هنا. الربط بالذكاء الاصطناعي: في الدقّات العالية تصير الحدود «دقيقة عملياً».

مثال (32.5-13): عامل δ في الحدّ السفلي المعطيات: δ من 0.05 إلى 0.01. المطلوب: أثره على الحدّ السفلي. الحل: الخطوة 1: الحدّ السفلي (32.9) لا يحتوي δ (بشرط $\delta \leq 1/4$). الخطوة 2: لكنّ حدوداً أدقّ تضيف $\ln(1/\delta)$ كما في العلوي. النتيجة: تأثير الثقة في الحدّ السفلي ضعيف أو معدوم في هذه الصيغة. الربط بالذكاء الاصطناعي: الثقة

رخيصة في الحدّين معاً.

مثال (14-5.32): هل «البيانات الضخمة» ضرورية دائماً؟ المعطيات: مسألة بسيطة بـ $d = 5$. المطلوب: الحاجة الفعلية. الحل: الخطوة 1: تحقّقي بـ $\varepsilon = 0.01$: $5(4.605)+3)/0.01 = 2603$. الخطوة 2: والحدّ السفلي $\frac{4}{0.32} = 13$. النتيجة: الحاجة بين 13 و 2600 — لا «مليارات» بالضرورة. الربط بالذكاء الاصطناعي: اختيار فئة صغيرة السعة يوفّر ميزانيات ضخمة.

مثال (15-5.32): القاعدة الذهبية المعطيات: مشروع ببيانات محدودة. المطلوب: القرار. الحل: الخطوة 1: إن كان الحدّ السفلي أكبر من ميزانيتك $\Rightarrow$ غيّر الفئة (قلّل d) أو اقبل دقّة أقلّ. الخطوة 2: لا أمل في «خوارزمية أفضل» تتجاوز الحاجز. النتيجة: النظرية تمنع إهدار الموارد على بحث مستحيل. الربط بالذكاء الاصطناعي: أحد أنفع استخدامات النظرية: معرفة متى لا نحاول.

أخطاء شائعة

- تفسير الحدّ السفلي كرقم دقيق (ثوابته متحفّظة جدّاً).
- تطبيقه خارج شروطه ($\varepsilon \le 1/8$، $\delta \le 1/4$).
- الظنّ أنّه يمنع التعلّم النشط أو الاستفادة من البنية (لا يمنعها عمليّاً).
- نسيان أنّه «أسوأ الحالات» على التوزيعات.
- الخلط بين حدود «أسوأ الحالات» وحدود «توزيع بعينه».

المبرهنة: بتجميع (4.32) و (6.32) مع بُعد VC لكلّ فئة:

$$n_{\text{تحقّقي}} \approx \frac{d\ln(1/\varepsilon)+\ln(1/\delta)}{\varepsilon}, \qquad n_{\text{غير متحيّز}} \approx \frac{d+\ln(1/\delta)}{\varepsilon^2} \tag{11.32}$$

وجدول بأبعاد VC الشائعة:

الفئة	d_{VC}
عتبات على $\mathbb{R}$	1
فترات على $\mathbb{R}$	2
اتحاد k فترات	$2k$
مستطيلات محورية في $\mathbb{R}^2$	4
نصف فضاءات في $\mathbb{R}^{d_0}$	d_0+1
عطف (conjunction) على p متغيّر	p
m أشجار محورية بـ ورقة في $\mathbb{R}^{d_0}$	$\Theta(m \log d_0)$

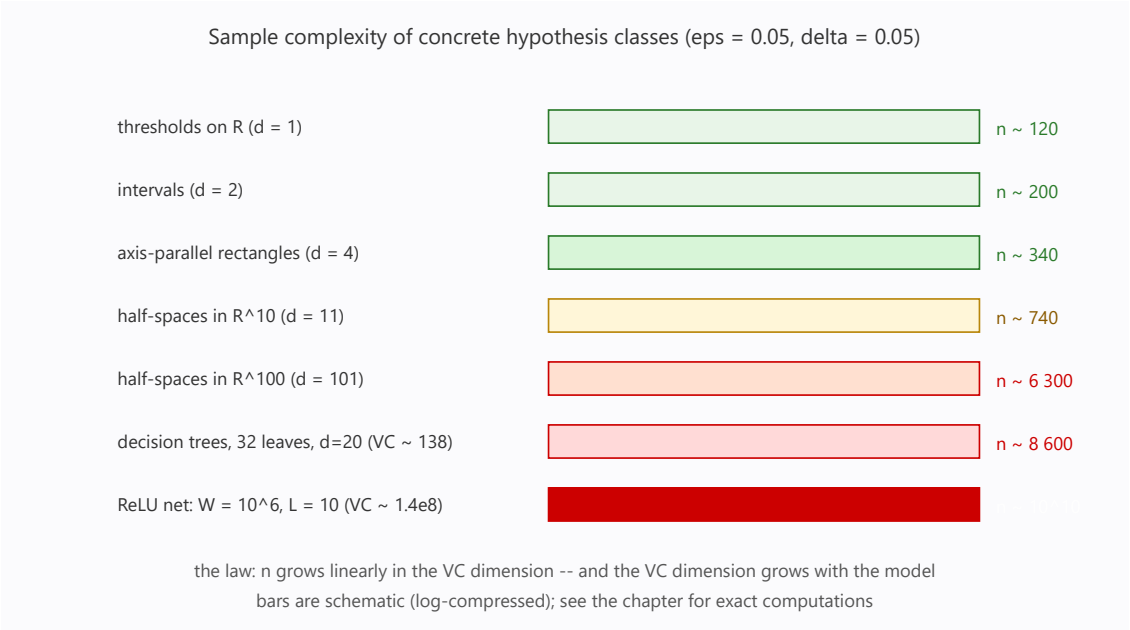
(12.32)

جدول الرموز

الرمز	المعنى	ملاحظة
d_0	بُعد المُدخلات	لا بُعد VC
k	عدد الفترات/الحدود	يضاعف السعة خطّياً
p	عدد المتغيّرات المنطقية	في العطف والـ DNF
m	عدد الأوراق	في الأشجار
$\ln(1/\varepsilon)$	عامل البحث	في الحالة التحقّقية
تقريب	العلاقات «$\approx$»	الرتبة لا الثابت

الرسم

<figure> الشكل<figcaption> 5.32: تعقيد العيّنة المطلوب لفئات شائعة عند $\varepsilon = 0.05$ و $\delta = 0.05$ (مضغوط



شكل ٥.٣٢: *
تعقيد العينة لفئات محددة

لوغاريتمياً).</figcaption> </figure>

البرهان

الخطوة 1: بتعويض d_{VC} المحسوب في الفصل 31 لكلّ فئة في (11.32).

الخطوة 2 (العطف): عطف على p متغيّر منطقي يكافئ اختيار مجموعة فرعية من المتغيّرات، ويُحطَم p متغيّر بالبناء المباشر $d_{\mathrm{VC}} = p \Rightarrow$.

الخطوة 3 (الأشجار): شجرة محورية بـ m ورقة تقسّم الفضاء إلى m مستطيلات، وسعة كلّ تقسيم تُجمَع فتعطي $\Theta(m \log d_0)$ (بناءً وحدّاً).

الخطوة 4 (باقي الصفوف): من الفصل 31 (1-2.31 حتى 6-2.31 و 4.31-10). ■

خمسة عشر مثالاً محلولاً

مثال (1-6.32): العتبات المعطيات: $d = 1$، $\varepsilon = 0.05$، $\delta = 0.05$. المطلوب: n تحقّقي. الحل: الخطوة 1: $120 = 0.05/(3 + 1(3.00))$. النتيجة: 120 عيّنة لتعلّم عتبة بدقّة 95%. الربط بالذكاء الاصطناعي: المعيار الذي يُقاس عليه كلّ ما بعده.

مثال (2-6.32): الفترات المعطيات: $d = 2$. المطلوب: n. الحل: الخطوة 1: $180 = 0.05/(3 + 2(3.00))$. النتيجة: 180 عيّنة. الربط بالذكاء الاصطناعي: نطاقات القيم الطبيعية (ضغط، سكر) تتعلّم ببيانات قليلة.

مثال (3-6.32): اتّحاد خمس فترات المعطيات: $k = 5 \Rightarrow d = 10$. المطلوب: n. الحل: الخطوة 1: $660 = 0.05/(3 + 10(3.00))$. النتيجة: 660 عيّنة — 5.5 ضعف الفترة الواحدة. الربط بالذكاء الاصطناعي: كلّ «نافذة زمنية» إضافية في كشف الأعطال تكلف مئات العيّنات.

مثال (4-6.32): المستطيلات المحورية المعطيات: $d = 4$. المطلوب: n. الحل: الخطوة 1: $(4(3.00) + 3)/0.05 = 300$. النتيجة: 300 عيّنة. الربط بالذكاء الاصطناعي: قواعد «منفذ × مدة» في الأمن السيبراني قابلة للتعلّم ببيانات متواضعة.

مثال (5-6.32): نصف فضاءات في $\mathbb{R}^{10}$ المعطيات: $d = 11$. المطلوب: n. الحل: الخطوة 1: $(11(3.00) + 3)/0.05 = 720$. النتيجة: 720 عيّنة ≈ 65 عيّنة لكلّ بُعد. الربط بالذكاء الاصطناعي: قاعدة إبهام عمليّة: عشرات العيّنات لكلّ خصيصة.

مثال (6-6.32): نصف فضاءات في $\mathbb{R}^{100}$ المعطيات: $d = 101$. المطلوب: n. الحل: الخطوة 1: $(101(3.00) + 3)/0.05 = 6120$. النتيجة: ستّة آلاف عيّنة. الربط بالذكاء الاصطناعي: في الأبعاد العالية «البيانات المتوسّطة» لا تكفي إلا بتنظيم أو هامش.

مثال (7-6.32): جذوع القرار المعطيات: $d = 2$. المطلوب: n. الحل: الخطوة 1: 180 عيّنة (كالفترات). النتيجة: المُنتقى الضعيف «رخيص» إحصائيّاً — وهذا سرّ التعزيز. الربط بالذكاء الاصطناعي: تمهيد مباشر للنظرية 7.32.

مثال (8-6.32): شجرة بـ 32 ورقة في $\mathbb{R}^{20}$ المعطيات: $d \approx 32 \log_2 20 = 138$. المطلوب: n. الحل: الخطوة 1: $(138(3.00) + 3)/0.05 = 8340$. النتيجة: 46 ضعف حاجة الجذع الواحد. الربط بالذكاء الاصطناعي: يبرّر «ضبط عمق الشجرة» عند ميزانية بيانات معلومة.

مثال (9-6.32): عطف على 100 متغيّر منطقي المعطيات: $d = 100 \Rightarrow p = 100$. المطلوب: n تحقّقي بـ $\varepsilon = 0.05$. الحل: الخطوة 1: $(100(3.00) + 3)/0.05 = 6060$. النتيجة: ستّة آلاف عيّنة لقاعدة «و» منطقية على مئة شرط. الربط بالذكاء الاصطناعي: أنظمة القواعد في كشف الاحتيال لها تكلفة بيانات محسوبة.

مثال (10-6.32): صيغة DNF بثلاثة حدود المعطيات: $k = 3$ حدود على p متغيّر. المطلوب: هل التعلّم سهل؟ الحل: الخطوة 1: سعة الفئة كبيرة؛ والأصعب: إيجاد أفضل فرضية (ERM) مسألة NP-صعبة. الخطوة 2: إحصائيّاً قابلة للتعلّم؛ حسابيّاً لا (في الإطار الصحيح). النتيجة: فصلٌ صريح بين القابلية الإحصائية والحسابية. الربط بالذكاء الاصطناعي: أوضح مثال على «ممكن إحصائيّاً ومستحيل حسابيّاً».

مثال (11-6.32): أقرب الجيران المعطيات: 1-NN بـ $d_{\text{VC}} = \infty$. المطلوب: هل هو قابل للتعلّم بـ PAC؟ الحل: الخطوة 1: بـ (3.32): لا (بالإطار القياسي) — رغم كونه متّسقاً شاملاً. الخطوة 2: الإطار distribution-free متشدّد هنا. النتيجة: «غير قابل للتعلّم بـ PAC $\neq$ «غير مفيد». الربط بالذكاء الاصطناعي: تحذير منهجي من سوء قراءة النتائج النظرية.

مثال (12-6.32): آلة نووية المعطيات: SVM بنواة غاوسية ($d_{\text{VC}} = \infty$)؛ نستخدم حدّ الهامش. المطلوب: تعقيد العيّنة. الحل: الخطوة 1: من (17.31): الفجوة $\frac{2BR_x}{\gamma\sqrt{n}} \approx \Rightarrow$ نشترط $\varepsilon \leq$. الخطوة 2: $n \geq \frac{4B^2R_x^2}{\gamma^2\varepsilon^2} \Rightarrow$ مستقل عن البعد. الخطوة 3: بـ $B = 1$، $R_x = 1$، $\gamma = 0.3$، $\varepsilon = 0.05$: $n \geq \frac{4}{0.09(0.0025)} = 17{,}778$. النتيجة: نحو 17,800 عيّنة بلا أيّ اعتماد على البعد. الربط بالذكاء الاصطناعي: هذا هو انتصار نظرية الهامش الذي عجز عنه بُعد VC.

مثال (13-6.32): شبكة عصبية المعطيات: $W = 10^6$، $L = 10 \Rightarrow d \approx 1.38 \times 10^8$؛ $\varepsilon = 0.05$. المطلوب: n تحقّقي. الحل: الخطوة 1: $(1.38 \times 10^8(3.00)+3)/0.05 = 8.3 \times 10^9$. النتيجة: 3.8 مليار عيّنة مقابل ملايين في الممارسة. الربط بالذكاء الاصطناعي: الفجوة بين النظرية والممارسة بمقدار ثلاث مراتب — موضوع الفصل 34.

مثال (14-6.32): فضاء منتهٍ بـ $|\mathcal{H}| = 10^6$ المعطيات: $d \leq \log_2(10^6) = 19.9$. المطلوب: n تحقّقي بـ $\varepsilon = 0.05$. الحل: الخطوة 1: $(19.9(3.00) + 3)/0.05 = 1254$. النتيجة: 1254 عيّنة لمليون فرضية. الربط بالذكاء الاصطناعي: دليل عددي على اقتصاد اللوغاريتم.

مثال (15-6.32): جدول القرار العملي المعطيات: ميزانية $n = 5000$ عيّنة وهدف $\varepsilon = 0.05$ تحقّقي. المطلوب: أكبر سعة مسموحة. الحل: الخطوة 1: من (11.32): $d \leq \frac{n\varepsilon - \ln(1/\delta)}{\ln(1/\varepsilon)} = \frac{250-3}{3} = 82.3$. النتيجة: لا تتجاوز

$82 \approx d_{\mathrm{VC}} \Rightarrow$ اختر نموذجاً بهذه السعة أو أقلّ. الربط بالذكاء الاصطناعي: أداة تخطيط عكسي: من البيانات إلى أقصى نموذج مسموح.

أخطاء شائعة

- استخدام بُعد المُدخلات d_0 بدل d_{VC} في (11.32).
- نسيان عامل $\ln(1/\varepsilon)$ في الحالة التحقّقية.
- تعميم نتائج فضاءات بعينها على أخرى «مشابهة ظاهريّاً».
- تجاهل أنّ الحدود «$\approx$» وليست أرقاماً نهائية.
- مقارنة فئات مختلفة بـ d_{VC} وحده بلا نظر للهامش أو الضجيج.

المبرهنة (Schapire 1990، Freund–Schapire 1997): متعلّمٌ **ضعيف** يحقّق خطأً $\frac{1}{2} - \gamma \leq$ (بـ $\gamma > 0$) على أيّ توزيع، يمكن تضخيمه إلى متعلّم **قوي** يحقّق خطأً ε كيفما صغر. لتعزيز AdaBoost بـ T جولة وهامش ضعف ثابت γ:

$$\text{خطأ التدريب} \;\leq\; \exp\!\big(-2T\gamma^2\big) \tag{13.32}$$

$$T \;\geq\; \frac{\ln(1/\varepsilon)}{2\gamma^2} \tag{14.32}$$

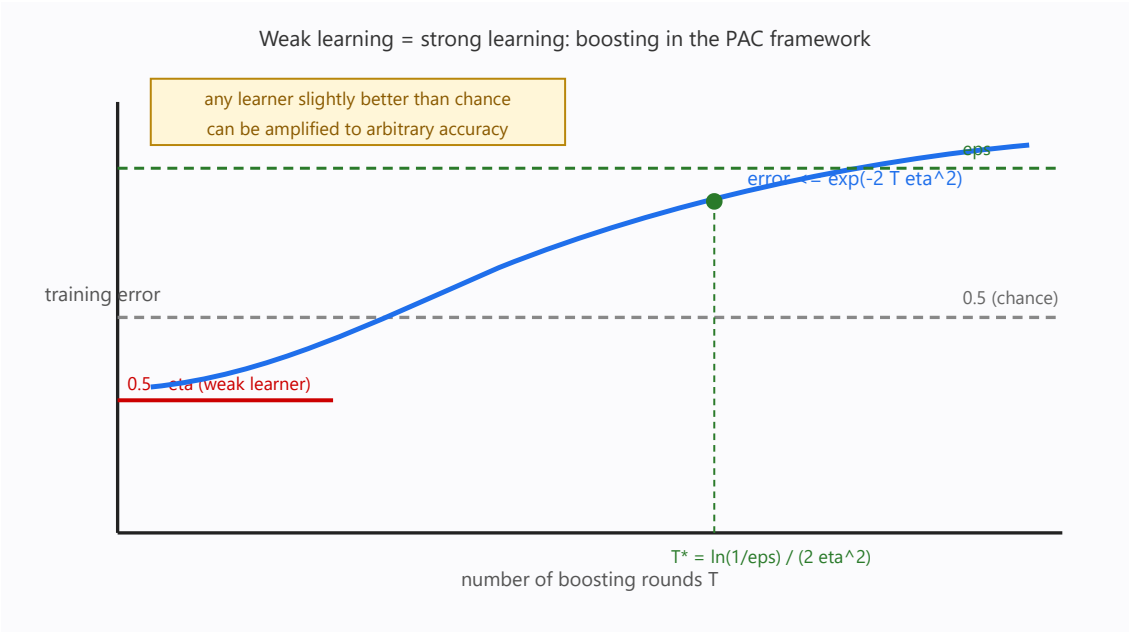
أي أنّ التعلّم الضعيف **يكافئ** التعلّم القوي: $\mathcal{H}$ قابلة للتعلّم الضعيف $\Leftrightarrow$ قابلة للتعلّم بـ PAC.

جدول الرموز

الرمز	المعنى	ملاحظة
γ	هامش الضعف (edge)	الخطأ $\frac{1}{2} - \gamma$
T	عدد جولات التعزيز	
$\exp(-2T\gamma^2)$	اضمحلال أُسّي	سبب قوّة التعزيز
متعلّم ضعيف	أفضل قليلاً من الصدفة	شرط ضعيف جدّاً
متعلّم قوي	خطأ ε كيفما صغر	النتيجة
$\Leftrightarrow$	تكافؤ	نتيجة مركزية في PAC

الرسم

<figure> الشكل<figcaption> 6.32: كلّ جولة تعزيز تُضاعف قوّة المتعلّم؛ وخطأ التدريب يهبط أُسّيّاً مع عدد الجولات.</figcaption> </figure>



شكل ٦.٣٢: *
التعزيز من الضعيف إلى القوي

البرهان (مخطّط)

الخطوة 1 (آلية AdaBoost): نحافظ على توزيع أوزان على العيّنات؛ في كلّ جولة ندرّب المتعلّم الضعيف على التوزيع المُعاد وزنه، ثمّ نرفع وزن الأمثلة التي أخطأها.

الخطوة 2 (تحليل الخطأ): باختيار معامل المتعلّم $\alpha_t = \frac{1}{2}\ln\frac{1-\epsilon_t}{\epsilon_t}$، نحصل على انخفاض في «الوزن الطبيعي» بمعامل $\sqrt{1-4\gamma_t^2} \Rightarrow$ بعد T جولة: خطأ التدريب $\le \exp(-2\sum_t \gamma_t^2) = \exp(-2T\gamma^2) \le \prod_t \sqrt{1-4\gamma_t^2}$. ■

الخطوة 3 (التعميم): بحدّ الهامش (17.31): التعزيز يرفع الهامش، فينقص حدّ التعميم رغم نموّ سعة التجميعة $O(Td\log(Td))$. ■

الخطوة 4 (التكافؤ): اتجاه «قوي ⇒ ضعيف» بديهي؛ واتجاه «ضعيف ⇒ قوي» هو مبرهنة شابير، وتثبتها خوارزمية التعزيز صراحةً. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.32): متعلّم ضعيف طفيف المعطيات: خطأ المتعلّم الضعيف $0.40 =$. المطلوب: γ. الحل: الخطوة 1: $\gamma = 0.10 - 0.40 = 0.5$. النتيجة: هامش 10 نقاط فوق الصدفة. الربط بالذكاء الاصطناعي: جذع قرار على بيانات صعبة كثيراً ما يعطي هذا الرقم.

مثال (2-7.32): كم جولة للوصول إلى 1%؟ المعطيات: $\gamma = 0.1$، $\varepsilon = 0.01$. المطلوب: T. الحل: الخطوة 1: $\ln(1/0.01) = 4.605$؛ $2\gamma^2 = 0.02$. الخطوة 2: $T \ge 4.605/0.02 = 230.3 \Rightarrow 231$ جولة. النتيجة: 231 جذعاً تكفي نظرياً لخطأ تدريب 1%. الربط بالذكاء الاصطناعي: أرقام قريبة ممّا يُستخدم فعلاً (مئات الأشجار).

مثال (3-7.32): هامش ضعف نصف الحجم المعطيات: $\gamma = 0.05$. المطلوب: T لنفس الهدف. الحل: الخطوة 1: $2\gamma^2 = 0.005$. الخطوة 2: $T \ge 4.605/0.005 = 921$. النتيجة: نصف الهامش ⇒ أربعة أضعاف الجولات. الربط بالذكاء الاصطناعي: العلاقة التربيعية تجعل جودة المتعلّم الضعيف حاسمة.

مثال (4-7.32): خطأ بعد 100 جولة المعطيات: $\gamma = 0.1$، $T = 100$. المطلوب: خطأ التدريب المضمون.

الحل: الخطوة 1: $\exp(-2) = 0.1353$ $\exp(-2(100)(0.01)) =$ ((. النتيجة: 13.5% — ما زال مرتفعاً. الربط بالذكاء الاصطناعي: التعزيز يحتاج مئات الجولات ليصبح «قوياً» فعلاً.

مثال (32.7-5): خطأ بعد 300 جولة المعطيات: $\gamma = 0.1$، $T = 300$. المطلوب: الخطأ. الحل: الخطوة 1: $\exp(-6) = 0.00248$. النتيجة: 0.25% خطأ تدريب. الربط بالذكاء الاصطناعي: الاضمحلال الأُسّي يعطي مكاسب سريعة في النهاية.

مثال (32.7-6): هامش أصغر وجولات أكثر المعطيات: $\gamma = 0.05$، $T = 500$. المطلوب: الخطأ. الحل: الخطوة 1: $\exp(-2.5) = 0.0821$ $\exp(-2(500)(0.0025)) =$ ((. النتيجة: 8.2% بعد خمسمئة جولة — أضعف من 300 جولة بـ $\gamma = 0.1$. الربط بالذكاء الاصطناعي: قوّة المتعلّم الضعيف أهمّ من عدد الجولات.

مثال (32.7-7): تكلفة التعزيز في تعقيد العيّنة المعطيات: جذوع بـ $d = 2$، $T = 231$؛ نريد $\varepsilon = 0.01$. المطلوب: n للتجميعة. الحل: الخطوة 1: بُعد VC للتصويت الأغلبي: $Td\ln(Td) = 231(2)\ln(462) = 2834 \approx$. الخطوة 2: $n \approx (2834(4.605) + 3)/0.01 = 1.31 \times 10^6$. النتيجة: 1.3 مليون عيّنة نظرياً مقابل 1221 عيّنة لجذع واحد! الربط بالذكاء الاصطناعي: حدود السعة تبالغ في تقدير تكلفة التعزيز — والممارسة أنجح.

مثال (32.7-8): المقارنة مع الجذع الواحد المعطيات: جذع واحد، $d = 2$، $\varepsilon = 0.01$. المطلوب: n. الحل: الخطوة 1: $(2(4.605) + 3)/0.01 = 1221$. الخطوة 2: لكنّ الجذع لا يستطيع أصلاً بلوغ $\varepsilon = 0.01$ (تحيزه عالٍ). النتيجة: المقارنة مضلّلة: الجذع أرخص لكنّه عاجز. الربط بالذكاء الاصطناعي: لا تُقارن تكلفة بلا قدرة.

مثال (32.7-9): تفسير الهامش لعدم الإفراط المعطيات: تعزيز بـ 1000 جولة وخطأ تدريب صفر. المطلوب: لماذا لا يفرط في الملاءمة؟ الحل: الخطوة 1: التعزيز يستمرّ في رفع هوامش الأمثلة الصحيحة بعد بلوغ الخطأ صفراً. الخطوة 2: حدّ الهامش (17.31) ينقص كلّما كبر الهامش المتوسط. النتيجة: «الهامش المتزايد» هو التفسير المقبول لظاهرة عدم الإفراط. الربط بالذكاء الاصطناعي: من أنجح تطبيقات نظرية الهامش في تفسير الممارسة.

مثال (32.7-10): متى يُفرط التعزيز؟ المعطيات: بيانات شديدة الضجيج. المطلوب: الخطر. الحل: الخطوة 1: التعزيز يركّز على الأمثلة الصعبة — وهي في الضجيج أمثلة خاطئة الوسم. الخطوة 2: فترتفع الحساسية للضجيج $\Rightarrow$ إفراط فعلي. النتيجة: التعزيز بلا حدود ضارّ في البيانات الملوّثة. الربط بالذكاء الاصطناعي: سبب شيوع معدّل التعلّم المنخفض والتوقّف المبكر في Gradient Boosting.

مثال (32.7-11): التعزيز المتدرّج عملياً المعطيات: XGBoost على بيانات جدولية بـ $n = 10^4$. المطلوب: ضبط عدد الجولات. الحل: الخطوة 1: استخدم التحقق المتقاطع و«التوقّف المبكر» (الفصل 30). الخطوة 2: لا تعتمد على (32.14) لتحديد T (فضفاض ويفترض γ ثابتاً). النتيجة: النظرية توجّه، والتحقق يقرّر. الربط بالذكاء الاصطناعي: العلاقة الصحيحة بين النظرية والممارسة.

مثال (32.7-12): تقدير γ من البيانات المعطيات: جذع أعطى خطأ 0.42 على التوزيع المتوازن. المطلوب: γ وعدد الجولات لـ $\varepsilon = 0.05$. الحل: الخطوة 1: $\gamma = 0.08$. الخطوة 2: $T \geq \ln(20)/(2(0.0064)) = 234$ $2.996/0.0128 =$. النتيجة: 234 جولة. الربط بالذكاء الاصطناعي: حساب سريع لإعداد أوّلي قبل الضبط التجريبي.

مثال (32.7-13): متعلّم أسوأ من الصدفة المعطيات: خطأ المتعلّم 0.6 =. المطلوب: هل يصلح للتعزيز؟ الحل: الخطوة 1: $0 > 0.1 - = 0.5 - 0.6 = \gamma$. الخطوة 2: بقلب مخرجاته يصير خطؤه $0.4 \Rightarrow 0.1 = \gamma$. النتيجة: «أسوأ من الصدفة» أسوأ من الصدفة فقط بمقدار الإشارة! الربط بالذكاء الاصطناعي: قاعدة عملية: اقلب المصنّف إن كان خطؤه $0.5 <$.

مثال (32.7-14): التعزيز متعدّد الأصناف المعطيات: 10 أصناف. المطلوب: هل يسري التحليل؟ الحل: الخطوة 1: نعم: نخفّض إلى ثنائي (واحد مقابل البقية) أو نعمّم الخسارة. الخطوة 2: شرط الضعف يصير: أفضل من $\frac{1}{K}$ (الصدفة).

النتيجة: نفس المبدأ بمقياس مختلف. الربط بالذكاء الاصطناعي: يفسّر نجاح التعزيز في مسائل متعدّدة التسمية.

مثال (15-7.32): متى نتوقّف؟ المعطيات: تعزيز على بيانات نظيفة. المطلوب: قاعدة التوقّف. الحل: الخطوة 1: راقب خطأ التحقّق؛ توقّف عند أول صعود مستمرّ. الخطوة 2: إن كان خطأ التدريب صفراً وخطأ التحقّق ما زال يهبط ⇒ استمرّ (الهامش يكبر). النتيجة: التوقّف قرار تجريبي لا نظري. الربط بالذكاء الاصطناعي: يوضّح حدود ما تستطيع النظرية تحديده.

أخطاء شائعة

- توقّع γ ثابتاً طوال الجولات (يتغيّر مع الأوزان).
- اعتبار (13.32) ضماناً لخطأ التعميم (هو لخطأ التدريب).
- التعزيز على بيانات شديدة الضجيج بلا توقّف مبكر.
- نسيان أنّ سعة التجميعة تنمو مع T (حدود VC تراها، والممارسة لا).
- استخدام متعلّم ضعيف قويّ جدّاً (فقدان فائدة التنويع).

التعريف: فئة $\mathcal{H}$ **قابلة للتعلّم بكفاءة** (efficiently PAC learnable) إذا تعلّمها خوارزمية بزمن حدودي في $1/\varepsilon$ و $1/\delta$ وبُعد التمثيل، مع تعقيد عيّنة حدودي. والمبرهنة المركزية هنا **سلبية**:

$$\text{قابلية التعلّم (حسابيّاً)} \not\Rightarrow \text{قابلية التعلّم (إحصائيّاً)} \tag{15.32}$$

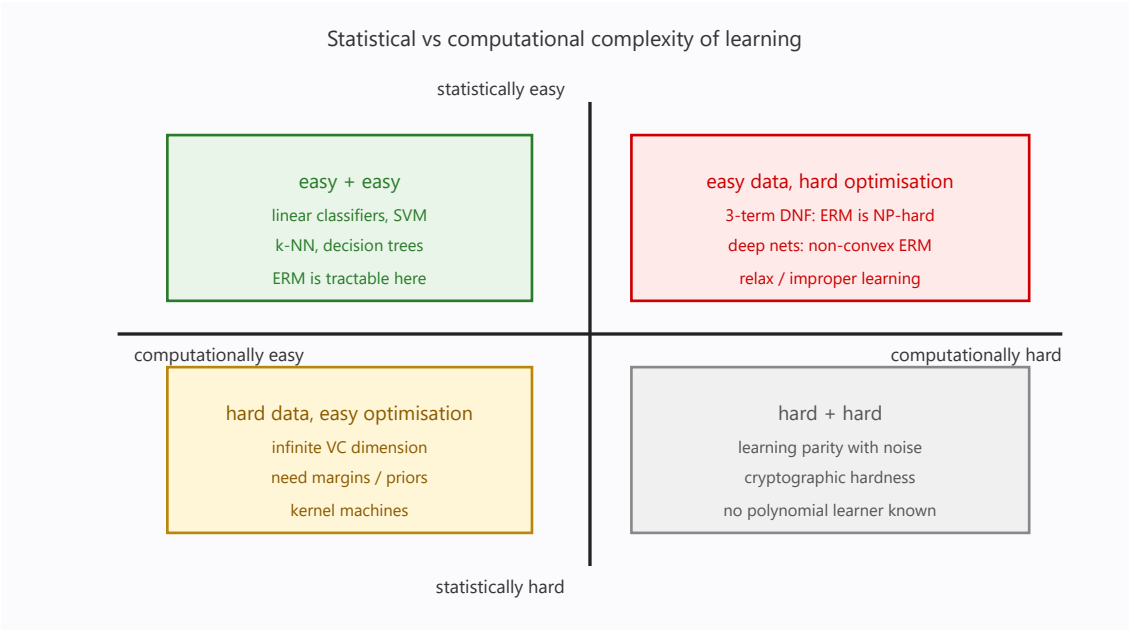
فمسألة ERM لصيغ DNF ثلاثية الحدود صعبة-NP، (Pitt–Valiant) ومسألة تعلّم التكافؤ (parity) مع الضجيج يفترض أنها صعبة حسابيّاً (أساس تشفيري)، في حين أنّ **التعلّم غير الصحيح** (الخروج من $\mathcal{H}$) قد يكون فعالاً حيث يعجز الصحيح.

جدول الرموز

الرمز	المعنى	ملاحظة
زمن حدودي	poly في المعاملات	البعد الحسابي
صحيح/غير صحيح	داخل/خارج $\mathcal{H}$	الثاني أقوى
صعب-NP	لا خوارزمية حدودية معروفة	نفسه ERM!
تعلّم التكافؤ	noise with parity	صعوبة مفترضة
استعلامات إحصائية	نموذج SQ	أدوات حدود سفلية حسابية
توزيع مخصّص	أسهل أحياناً	distribution Unfiorm

الرسم

<figure> الشكل<figcaption> 7.32: أربعة أرباع: ما يسهل إحصائيّاً وحسابيّاً، وما يسهل بأحدهما ويصعب بالآخر، وما يصعب بهما.</figcaption> </figure>



شكل ٧.٣٢: *
التعقيد الحسابي للتعلم

البرهان (مخطّط)

الخطوة 1 (صعوبة ERM): بتخفيض (reduction) من مسألة تغطية/تلوين معروفة: إيجاد فرضية في $\mathcal{H}$ تحقّق خطأً أدنى على عيّنة معطاة يكافئ مسألة قرار صعبة-NP $\Rightarrow$ لا خوارزمية حدودية (إلّا إذا P=NP).

الخطوة 2 (الصحيح مقابل غير الصحيح): قد تكون الفئة «الصحيحة» صعبة البحث، لكنّ فئةً أكبر تحتويها وتسمح بتحسين محدّب تكون سهلة؛ فيُتعلَّم غيرَ صحيح ويُضمن نفس الحدّ الإحصائي تقريباً.

الخطوة 3 (التكافؤ مع الضجيج): تعلّم دوالّ التكافؤ مع ضجيج يكافئ فكّ تشفير معروف $\Rightarrow$ الصعوبة الحسابية تفترض صعوبة تشفيرية قياسية. ■

الخطوة 4 (نموذج SQ): الخوارزميات التي ترى البيانات عبر «استعلامات إحصائية» فقط لا تستطيع تعلّم التكافؤ بعدد حدودي من الاستعلامات $\Rightarrow$ يفسّر صعوبة كثير من الطرق العملية (ومنها التدرّج) على مسائل بعينها. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.32): تعريف الكفاءة المعطيات: خوارزمية بزمن $O(n^2 d)$ وتعقيد عيّنة $O(d/\varepsilon)$. المطلوب: هل هي كفؤة؟ الحل: الخطوة 1: الزمن حدودي في n و d، و n حدودي في $1/\varepsilon$ و $1/\delta$. النتيجة: نعم، كفؤة بـ PAC. الربط بالذكاء الاصطناعي: الانحدار الخطّي والـ SVM يحقّقان ذلك.

مثال (2-8.32): ERM لصيغ DNF الثلاثية المعطيات: $\mathcal{H}$ = صيغ DNF بثلاثة حدود على p متغيّر. المطلوب: هل التعلّم الصحيح فعال؟ الحل: الخطوة 1: إيجاد أفضل صيغة مسألة صعبة-NP (Pitt–Valiant 1988). الخطوة 2: إحصائيّاً الفئة قابلة للتعلّم (سعتها منتهية)، حسابيّاً لا. النتيجة: فصل بيّن بين النوعين. الربط بالذكاء الاصطناعي: مبرّر نظري للبحث عن بدائل قابلة للتحسين.

مثال (3-8.32): التعلّم غير الصحيح ينقذ الموقف المعطيات: نفس الفئة السابقة. المطلوب: هل يمكن التعلّم بكفاءة بطريقة أخرى؟ الحل: الخطوة 1: نعم: بتوسيع الفئة إلى فضاء أكبر قابل للتحسين المحدّب (مثل نواة متعدّدة الحدود).

الخطوة 2: الضمان الإحصائي يبقى (بحدود السعة للفئة الموسّعة). النتيجة: التعلّم غير الصحيح أداة أساسية لا حيلة. الربط بالذكاء الاصطناعي: كلّ «الاسترخاءات المحدّبة» في تعلّم الآلة من هذا القبيل.

مثال (32.8-4): الشبكات العصبية المعطيات: تدريب شبكة بسيطة مسألة غير محدّبة. المطلوب: هل التعلّم كفؤ؟ الحل: الخطوة 1: إيجاد الحلّ الأمثل العالمي صعب-NP في العموم. الخطوة 2: لكنّ هبوط التدرّج يعمل عملياً بإيجاد حلول جيّدة. النتيجة: الكفاءة «العملية» لا «المضمونة». الربط بالذكاء الاصطناعي: أكبر فجوة بين النظرية والممارسة — موضوع الفصل 34.

مثال (32.8-5): تعلّم التكافؤ مع الضجيج المعطيات: $f(x) = x_{i_1} \oplus \cdots \oplus x_{i_k}$ مع قلب الوسم باحتمال 0.1. المطلوب: الصعوبة. الحل: الخطوة 1: تعلّمها يكافئ فكّ شفرة قياسية $\Rightarrow$ يُفترض أنّه غير فعال. الخطوة 2: سعتها منتهية $(d = k)$ فهي قابلة للتعلّم إحصائياً بـ $n \approx k/\varepsilon$. النتيجة: مثال حاسم على انفصال النوعين. الربط بالذكاء الاصطناعي: دوالّ التكافؤ تظهر في اختبارات صعوبة التعلّم العميق.

مثال (32.8-6): توزيع مخصّص أسهل المعطيات: تعلّم DNF على التوزيع **المنتظم** (unfiorm). المطلوب: هل يسهل؟ الحل: الخطوة 1: نعم: على التوزيع المنتظم توجد خوارزميات فعّالة (Jackson). الخطوة 2: على توزيعات عامّة يبقى صعباً. النتيجة: قيد «الاستقلال عن التوزيع» مكلف حسابيّاً أيضاً. الربط بالذكاء الاصطناعي: استغلال بنية التوزيع مكسب حسابي لا إحصائي فقط.

مثال (32.8-7): نموذج الاستعلامات الإحصائية المعطيات: خوارزمية ترى البيانات عبر متوسطات فقط (كالتدرّج). المطلوب: حدودها. الحل: الخطوة 1: في نموذج SQ، تعلّم التكافؤ يتطلّب عدداً أُسّيّاً من الاستعلامات. الخطوة 2: هبوط التدرّج «يرى» البيانات عبر متوسطات $\Rightarrow$ يندرج في النموذج. النتيجة: حدود سفلية حسابية تطال الطرق العملية فعلاً. الربط بالذكاء الاصطناعي: يفسّر صعوبة بعض المسائل على الشبكات رغم سعتها.

مثال (32.8-8): الاستبدال المحدّب المعطيات: خسارة 0-1 غير قابلة للتحسين المباشر. المطلوب: الحلّ. الحل: الخطوة 1: استبدلها بـ hinge أو إنتروبيا تقاطعية (محدّبة، قابلة للتحسين). الخطوة 2: ثمن الاستبدال: الخسارة البديلة ليست الخسارة الأصلية. النتيجة: المقايضة بين الكفاءة الحسابية والأمانة للهدف. الربط بالذكاء الاصطناعي: كلّ خسائر التدريب في تعلّم الآلة بدائل من هذا النوع.

مثال (32.8-9): فصل زمن-عيّنة المعطيات: مسألة تحتاج $n = 10^4$ عيّنة وزمن $O(n^3)$ لكلّ تدريب. المطلوب: المورد الحاكم. الحل: الخطوة 1: الزمن 10^{12} عملية $\Rightarrow$ الحساب هو القيد لا البيانات. الخطوة 2: الحل: طرق تقريبية (هبوط تدرّجي، عيّنات فرعية، تقريبات مصفوفية). النتيجة: في الممارسة القيد الحسابي يسبق الإحصائي غالباً. الربط بالذكاء الاصطناعي: يبرّر الاهتمام بكفاءة المُحسّنات (الفصل 23).

مثال (32.8-10): الطرق النووية محدّبة المعطيات: SVM نواة. المطلوب: لماذا هي «سهلة حسابيّاً»؟ الحل: الخطوة 1: المسألة الثنائية محدّبة (تربيعية) مع قيود صندوقية. الخطوة 2: حلول حدودية مضمونة (خوارزميات QP، SMO). النتيجة: هذا سبب شيوعها قبل عصر الشبكات العميقة. الربط بالذكاء الاصطناعي: الكفاءة الحسابية ميزة تنافسية لا تفصيل.

مثال (32.8-11): أشجار القرار بالجشع المعطيات: بناء شجرة مثالية صعب-NP (مثل بناء CART في العموم). المطلوب: الممارسة. الحل: الخطوة 1: نستخدم الجشع: أفضل تقسيم عند كلّ عقدة. الخطوة 2: بلا ضمان أمثلية، لكنّه سريع ويعمل جيّداً. النتيجة: كفاءة حسابية مقابل أمثلية إحصائية. الربط بالذكاء الاصطناعي: النمط المتكرّر «جشع سريع $\gg$ أمثل بطيء».

مثال (32.8-12): متى نختار فئة أصغر لأسباب حسابية؟ المعطيات: فئة كبيرة دقيقة لكنّ تدريبها بطيء جدّاً. المطلوب: القرار. الحل: الخطوة 1: إن كان خطأ التحسين هو المهيمن (الفصل 30)، فالفئة الكبيرة تضرّ. الخطوة 2: اختر

فئة يمكن تدريبها حتى التقارب في الميزانية. النتيجة: القرار بالميزانية لا بالسعة وحدها. الربط بالذكاء الاصطناعي: صلة مباشرة بتفكيك الأخطاء الثلاثة (8.30).

مثال (8.32-13): التعلّم بكفاءة في ظلّ القيود الحديثة المعطيات: تدريب بخصوصية تفاضلية أو بقيود ذاكرة. المطلوب: الأثر النظري. الحل: الخطوة 1: القيود ترفع تعقيد العيّنة المطلوب (إضافة ضجيج/ضغط). الخطوة 2: لكنّها لا تغيّر الرتبة في حالات كثيرة. النتيجة: إطار PAC يو accommodates القيود الحديثة. الربط بالذكاء الاصطناعي: تمهيد للفصل 33 (الاستقرار والخصوصية).

مثال (8.32-14): «قابل للتعلّم» $\neq$ «قابل للتطبيق» المعطيات: فئة قابلة للتعلّم بـ PAC تعقيدها $n = 10^6$ وزمن تدريب أُسّي. المطلوب: الحكم العملي. الحل: الخطوة 1: النظرية تقول «ممكن»؛ الممارسة تقول «لا يمكن». الخطوة 2: البديل: فئة أصغر أو تقريب. النتيجة: النظرية شرط لازم لا كافٍ للنجاح العملي. الربط بالذكاء الاصطناعي: تواضع منهجي مطلوب في قراءة النتائج النظرية.

مثال (8.32-15): جدول القرار الختامي المعطيات: مشروع جديد. المطلوب: قائمة فحص. الحل: الخطوة 1: هل d_{VC} منتهٍ؟ (إن لا $\Rightarrow$ أضف هامشاً/تنظيماً/انحيازاً). الخطوة 2: كم عيّنة يلزم؟ n بـ (11.32). الخطوة 3: هل يمكن حساب ERM بكفاءة؟ (إن لا $\Rightarrow$ استرخاء أو توسيع الفئة). الخطوة 4: هل خطأ التحسين مقبول في الميزانية؟ (الفصل 30). النتيجة: أربع خطوات تغطّي الإحصاء والحساب معاً. الربط بالذكاء الاصطناعي: خلاصة الجزء السادس في إجراء واحد.

أخطاء شائعة

- الخلط بين صعوبة-NP ERM واستحالة التعلّم الإحصائي.
- افتراض أنّ «قابلية التعلّم بـ «PAC تعني إمكانية التطبيق.
- تجاهل التعلّم غير الصحيح كأداة مشروعة.
- تعميم صعوبة «أسوأ الحالات» على الحالات العملية.
- نسيان أنّ القيود الحديثة (خصوصية، ذاكرة، طاقة) تضاف إلى تعقيد العيّنة.

ملخّص النظريات

النظرية	المفهوم	الأهمّية
2.32 إطار PAC	$\mathbb{P}[R \le \varepsilon] \ge 1-\delta$	التعريف الدقيق للتعلّم
3.32 مبرهنة التأسيس	$d_{\text{VC}} < \infty \Leftrightarrow$ قابل للتعلّم	تصنيف تامّ
4.32 غير المتحيّز	$R \le \inf_{\mathcal{H}} R + \varepsilon$ و $n \propto 1/\varepsilon^2$	الحالة الواقعية
5.32 حدود سفلى	$n \ge (d-1)/(32\varepsilon)$	لا خوارزمية أفضل
6.32 فئات محدّدة	n من d_{VC}	أرقام قابلة للاستخدام
7.32 التعزيز	$\exp(-2T\gamma^2)$	الضعيف = القوي
8.32 التعقيد الحسابي	ERM قد يكون صعباً-NP	إحصاء $\neq$ حساب

عشرون تمريناً (مع إجابات مختصرة)

١. ما معنى PAC؟ (على الأرجح تقريباً صحيح)

٢. صيغة تعريف PAC؟ ($\mathbb{P}[R \le \varepsilon] \ge 1-\delta$)

٣. مبرهنة التأسيس لـ PAC؟ (d_{VC} منتهٍ $\Leftrightarrow$ قابل للتعلّم)

٤. تعقيد العيّنة التحقّقي؟ ($O((d\ln(1/\varepsilon)+\ln(1/\delta))/\varepsilon)$)

٥. وغير المتحيّز؟ ($\Theta((d+\ln(1/\delta))/\varepsilon^2)$)

٦. لماذا التحقّقي أسرع؟ (لأنّ خطأ التدريب صفر)

٧. حدّ سفلي تحقّقي؟ ($n \geq (d-1)/(32\varepsilon)$)

٨. هل يفيد التعلّم غير الصحيح إحصائيًّا؟ (لا، حسابيًّا نعم)

٩. d_{VC} للعتبات؟ (1)

١٠. d_{VC} للفترات؟ (2)

١١. d_{VC} لاتّحاد k فترات؟ ($2k$)

١٢. d_{VC} لنصف فضاءات في $\mathbb{R}^{d_0}$؟ (d_0+1)

١٣. d_{VC} للمستطيلات المحورية في $\mathbb{R}^2$؟ (4)

١٤. تعريف المتعلّم الضعيف؟ (خطأ $\leq \frac{1}{2}-\gamma$)

١٥. خطأ AdaBoost بعد T جولة؟ ($\leq \exp(-2T\gamma^2)$)

١٦. كم جولة لـ ε؟ ($T \geq \ln(1/\varepsilon)/(2\gamma^2)$)

١٧. هل التكافؤ قابل للتعلّم إحصائيًّا؟ (نعم) وحسابيًّا؟ (يفترض لا)

١٨. لماذا ERM قد لا يكفي؟ (صعوبة حسابية لا إحصائية)

١٩. ماذا يفعل غير الصحيح؟ (يتعلّم من فئة موسّعة)

٢٠. هل قابلية التعلّم تكفي للتطبيق؟ (لا، تحتاج كفاءة حسابية)

فهرس الرموز

الرمز	المعنى
$\varepsilon,\ \delta$	الدقّة واحتمال الفشل
$m_{\mathcal{H}}$	تعقيد العيّنة
$d,\ d_{\text{VC}}$	بُعد فابنيك–تشروننكس
γ	هامش الضعف في التعزيز
T	عدد جولات التعزيز
صحيح/غير صحيح	داخل/خارج $\mathcal{H}$
$\inf_{\mathcal{H}} R$	أفضل ما في الفئة

مراجع

- Valiant — «A Theory of the Learnable» (1984) — ميلاد إطار PAC.
- Ehrenfeucht, Blumer, Haussler & Warmuth — «Learnability and the Vapnik-Chervonenkis Dimension» (1989).
- Vapnik & Chervonenkis — «On the Uniform Convergence...» (1971).
- Vazirani & Kearns — *An Introduction to Computational Learning Theory* (1994).
- Schapire — «The Strength of Weak Learnability» (1990).
- Schapire & Freund — «A Decision-Theoretic Generalization of On-Line Learning» (1997).
- Valiant & Pitt — «Computational Limitations on Learning from Examples» (1988).
- Kearns — «Efficient Noise-Tolerant Learning from Statistical Queries» (1998).
- Ben-David & Shalev-Shwartz — *Understanding Machine Learning* (الفصول 6 و 7).
- Mohri, Talwalkar & Rostamizadeh — *Foundations of Machine Learning* (الفصل 2 و 3).

خاتمة: أكملنا الآن «مثلّث النظرية»: بُعد VC (31) يمنح السعة، و PAC (32) يمنح تعقيد العيّنة، والحدود السفلية تمنع الأوهام. لكنّ كلّ هذه الحدود **لا تعتمد على الخوارزمية**: خوارزمتان تبحثان في $\mathcal{H}$ نفسه تنالان الحدّ ذاته. والواقع يخالف ذلك — فـ SGD المبكّر يعمّم خيراً من SGD الطويل على الشبكة نفسها. **الفصل 33** يعالج هذا النقص بإدخال خاصية الخوارزمية نفسها: **الاستقرار**.

الاستقرار الخوارزمي والتعميم

«ليس المهمّ ما يستطيع فضاء الفرضيات تمثيله؛ المهمّ ما تختاره الخوارزمية حين تبدّل نقطةً واحدة في العيّنة.»

في الفصل الثلاثين وضعنا إطار التعلّم: خطرٌ R مجهول، وخطرٌ تجريبي $\hat{R}_S$ محسوب، ومبدأ ERM/SRM للربط بينهما. وفي الفصل الحادي والثلاثين قِسْنا سعة فضاء الفرضيات بِبُعد VC وبمتوسط Rademacher. وفي الفصل الثاني والثلاثين صغنا ذلك بلغة PAC. كلّ تلك الحدود تشترك في خاصية واحدة: **لا ترى الخوارزمية.** إنّها تسأل «كم اتّسع $\mathcal{H}$؟» ولا تسأل «كيف تبحث فيه؟». لذلك تصمت تماماً أمام الشبكات العميقة المفرطة المعلمات، حيث $p \gg n$ وأيّ حدّ سعة يتجاوز الواحد.

هذا الفصل يقلب المنظور. بدل أن نسأل عن الفضاء، نسأل عن **الخوارزمية** A: لو بدّلنا نقطةً واحدة في عيّنة التدريب، كم يتغيّر ما تعلّمته؟ هذه الحساسية — وتُسمّى **الاستقرار الخوارزمي** — تكفي وحدها لإنتاج حدّ تعميم، بل وتكفي لتفسير التنظيم، والتوقّف المبكر، والتحقق المتقاطع، وحتّى الخصوصية التفاضلية. الاستقرار هو الخيط الذي يربط بينها كلّها.

سبع نظريات:

- **2.33 الاستقرار الخوارزمي وحدّ التعميم (Bousquet–Elisseeff)** — تعريف β-الاستقرار الموحّد والحدّ $R \le \hat{R} + 2\beta + (4n\beta + M)\sqrt{\ln(1/\delta)/2n}$.
- **3.33 التنظيم القوي ⇒ استقرار** — λ-تحدّب قويّ وخسارة L-لبشيتزية تعطيان $\beta \le 2L^2/(\lambda n)$.
- **4.33 استقرار هبوط التدرّج العشوائي (Hardt–Recht–Singer)** — $\beta \le \frac{2L^2}{n}\sum_t \alpha_t$ في الحالة المحدّبة الملساء، ونموّ الحدّ مع T في غير المحدّبة.
- **5.33 الاستقرار والتحقق المتقاطع** — متى يكون مقدّر CV موثوقاً ومتى يخذلنا.
- **6.33 استقرار الخوارزميات التكرارية** — التوقّف المبكر، توسيط المتكرّرات، حجم الدفعة، معدّل الخطوة.
- **7.33 الخصوصية التفاضلية ⇒ الاستقرار ⇒ التعميم** — خوارزمية ε-DP تعمّم بفجوة $O(\varepsilon)$، و DP-SGD بوصفه منظّماً.
- **8.33 الاستقرار في الشبكات العميقة ومقارنة المناهج** — حدود السعة مقابل حدود الاستقرار، وتمهيد الفصل 34.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
A	خوارزمية التعلّم: $A : S \mapsto h$	**محور هذا الفصل**
$S = \{z_1, \dots, z_n\}$	عيّنة التدريب، $z_i = (x_i, y_i)$	$\mathcal{D}$ من i.i.d.
$S^{i,z}$	العيّنة بعد استبدال z_i بـ z	جارةٌ لـ S
S^{-i}	العيّنة بعد حذف z_i	تُستخدم في LOO
β	ثابت **الاستقرار الموحّد**	كلّما صغر كان الحدّ أفضل
β_e	استقرار الخطأ	التغيّر في قيمة الخسارة
β_h	استقرار الفرضية	التغيّر في الفرضية نفسها
M	سقف الخسارة: $\ell \in [0, M]$	شرط حدود التركيز (الفصل 17)
L	ثابت لبشيتز للخسارة في w	$\|\nabla_w \ell\| \le L$
λ	قوّة التنظيم / التحدّب القوي	$\frac{\lambda}{2}\|w\|^2$
α_t	معدّل الخطوة في الخطوة t	من الفصل 23
T	عدد خطوات التحسين	يلعب دور عكس التنظيم
b	حجم الدفعة (minibatch)	
$\varepsilon, \delta_{\mathrm{DP}}$	ميزانية الخصوصية التفاضلية	التمييز عن δ مستوى الثقة
C	سقف قصّ التدرّج في DP-SGD	يحدّ حساسية المثال الواحد
σ	معلَم ضجيج غاوس في DP-SGD	
$\widehat{R}_{CV}$	مقدّر التحقق المتقاطع	

الاتفاقيات: الخسارة غير سالبة ومحدودة بـ $[0, M]$ كلّما استخدمنا متراجحات التركيز، والعيّنة i.i.d. دائماً ما لم نذكر خلاف ذلك. نرمز بـ $\mathbb{E}$ للتوقّع تحت $\mathcal{D}$ وبـ $\hat{\mathbb{E}}$ للتوقّع التجريبي. وحين نقول «الخوارزمية مستقرّة» فإنّما نقصد حساسيتها لتبديل **مثال تدريب واحد**، لا ثباتها العددي ولا مقاومتها للاضطراب في المُدخلات.

علاقة هذا الفصل بما قبله: الفصل 30 أعطانا التحيز–التباين بوصفه لغةً وصفية، والفصل 31 أعطانا سعةً لا تعتمد على الخوارزمية، والفصل 32 أعطانا ضمان PAC بمعلمة سعة. الفصل 33 يعطينا الضمان نفسه **بمعلمة خوارزمية** β، وهي — بعكس بُعد VC — قابلة للقياس التجريبي ومتاحة في الشبكات العميقة.

التعريف (الاستقرار الموحّد): نقول إنّ خوارزمية التعلّم A مستقرّة توحيديّاً بثابت β بالنسبة لدالة الخسارة ℓ إذا كان لكلّ عيّنة S ولكلّ فهرس $i \in \{1, \dots, n\}$ ولكلّ نقطة z:

$$\sup_{S,\, i,\, z} \; \sup_{z'} \Big| \, \ell\big(A(S), z'\big) \; - \; \ell\big(A(S^{i,z}), z'\big) \, \Big| \; \le \; \beta \tag{1.33}$$

حيث $S^{i,z}$ هي العيّنة S بعد استبدال مثالها الـ i بالنقطة z.

المبرهنة (الاستقرار $\Rightarrow$ التعميم): لتكن ℓ محصورة في $[0, M]$ ولتكن A مستقرّة توحيديّاً بثابت β. فلكلّ $\delta \in (0, 1)$، وباحتمال $\ge 1 - \delta$ على سحب $S \sim \mathcal{D}^n$:

$$R\big(A(S)\big) \; \le \; \hat{R}_S\big(A(S)\big) \; + \; 2\beta \; + \; \big(4n\beta + M\big)\sqrt{\frac{\ln(1/\delta)}{2n}} \tag{2.33}$$

كما أنّ الفجوة بالتوقّع تحقق

$$\Big| \, \mathbb{E}_S\big[R(A(S))\big] - \mathbb{E}_S\big[\hat{R}_S(A(S))\big] \, \Big| \; \le \; \beta \tag{3.33}$$

ملاحظة على الثوابت:

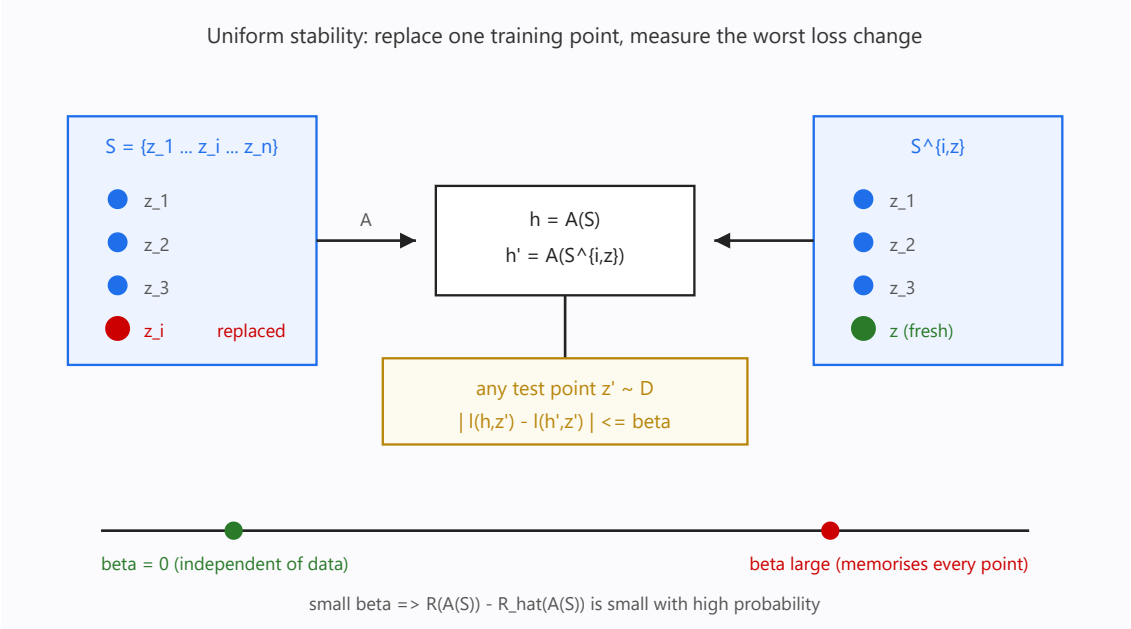
الثوابت 2 و 4 ليست مقدّسة؛ مراجع مختلفة تعطي β أو 2β في (2.33) و $2n\beta$ أو $4n\beta$ في حدّ التركيز، بحسب تعريف الاستقرار (موحّد أم بالمتوسط) وبحسب تفاصيل تطبيق متراجحة McDiarmid. الصيغة أعلاه هي الصيغة المتحفّظة الشائعة في الأدبيات.

جدول الرموز

الرمز	المعنى	ملاحظة
β	ثابت الاستقرار الموحّد	صفر يعني أنّ A لا ترى العيّنة أصلاً
$S^{i,z}$	عيّنة مجاورة	تختلف في مثال واحد
M	سقف الخسارة	$M = 1$ في خسارة 0-1
$n\beta$	**الكمية الحاكمة**	الحدّ مفيد إذا $n\beta = O(1)$
2β	حدّ الفجوة بالتوقّع	لا يعتمد على δ
$(4n\beta + M)\sqrt{\cdot}$	حدّ التركيز	يعتمد على δ و n

الرسم

<figure> الشكل<figcaption> 1.33: الاستقرار الموحّد: نبدّل مثالاً واحداً في S، ثمّ نقيس أسوأ تغيّر في الخسارة على



شكل ١.٣٣: *
تبديل نقطة تدريب واحدة وقياس التغير في الخسارة

أيّ نقطة اختبار z'.</figcaption></figure>

البرهان

الخطوة 1 (حيلة التبادل): ليكن z نقطةً مستقلّة عن S و i فهرساً موحّداً. التبديل $(S, z) \mapsto (S^{i,z}, z_i)$ حافظ للقياس لأنّ المتغيّرات $(z_1, \dots, z_n, z)$ قابلة للتبادل، فـ

$$\mathbb{E}\big[\ell(A(S), z)\big] \;=\; \mathbb{E}\big[\ell(A(S^{i,z}), z_i)\big]$$

الخطوة 2 (الفجوة بالتوقّع): بطرح $\mathbb{E}[\hat{R}_S] = \mathbb{E}[\ell(A(S), z_i)]$ يبقى $\mathbb{E}[R] - \mathbb{E}[\hat{R}] = \mathbb{E}[\ell(A(S^{i,z}), z_i) - \ell(A(S), z_i)] \le \beta$ بالاستقرار الموحّد، وهو (3.33). ■

الخطوة 3 (التركيز): لـ $\Psi = R - \hat{R}$، استبدال z_j يغيّر R بمقدار $\le \beta$ (بتعريف الاستقرار) ويغيّر $\hat{R}$ بمقدار $\le M/n + \beta$، فـ $c_j \le 4\beta + M/n$؛ ومتراجحة McDiarmid (الفصل 17) مع $\sum_j c_j^2 = n(4\beta + M/n)^2$ تعطي احتمال تجاوز δ عند $t = (4n\beta + M)\sqrt{\ln(1/\delta)/(2n)}$. ■

الخطوة 4 (الفرق عن الفصلين 31 و 32): لا يظهر في (2.33) لا d ولا $\mathfrak{R}_n$ ولا $|\mathcal{H}|$: الحدّ دالّة في الخوارزمية A وحدها. خوارزمتان تبحثان في $\mathcal{H}$ نفسه تحصلان على حدّ السعة ذاته وعلى حدّين مختلفين بالاستقرار. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.33): حساب الحدّ المرجعي المعطيات: $n = 1000$، $\beta = 0.001$، $M = 1$، $\delta = 0.05$. المطلوب: حدّ الفجوة من (2.33). الحل: الخطوة 1: $\sqrt{\ln(20)/2000} = \sqrt{0.0014979} = 0.03870$. الخطوة 2: $4n\beta = 4$، فـ $(4 + 1)(0.03870) = 0.19350$. الخطوة 3: $2\beta = 0.002$، والمجموع 0.19550. النتيجة: الفجوة لا تتجاوز 0.196 باحتمال 95%. الربط بالذكاء الاصطناعي: رقمٌ كبير لكنّه **غير فارغ**؛ قارن بحدود السعة في الشبكات التي تتجاوز الواحد.

مثال (2-2.33): خوارزمية أكثر استقراراً بعشر مرّات المعطيات: نفس الإعدادات لكن $\beta = 0.0002$. المطلوب: الحدّ الجديد والتحسّن. الحل: الخطوة 1: $4n\beta = 0.8$، فـ $(1.8)(0.03870) = 0.06966$. الخطوة 2: $2\beta = 0.0004$، المجموع 0.07006. الخطوة 3: النسبة $0.19550/0.07006 = 2.79$. النتيجة: تحسين الاستقرار بعشرة أضعاف حسّن الحدّ 2.8 مرّة فقط. الربط بالذكاء الاصطناعي: الحدّ حسّاس لـ β لكن بصورة مخفّفة، لأنّ 2β صغير أمام حدّ التركيز.

مثال (3-2.33): أثر مستوى الثقة δ المعطيات: $n = 1000$، $\beta = 0.0002$، $M = 1$، $\delta \in \{0.05, 0.01, 0.001\}$. المطلوب: الحدّ في الحالات الثلاث. الحل: الخطوة 1: $\delta = 0.05$ أعطى 0.07006. الخطوة 2: $\delta = 0.01$: $\sqrt{4.6052/2000} = 0.047984$، فـ $(1.8)(0.047984) + 0.0004 = 0.08677$. الخطوة 3: $\delta = 0.001$: $\sqrt{6.9078/2000} = 0.058769$، فـ $(1.8)(0.058769) + 0.0004 = 0.10618$. النتيجة: تشديد الثقة مئة ضعف رفع الحدّ من 0.070 إلى 0.106 فقط. الربط بالذكاء الاصطناعي: الاعتماد على δ لوغاريتمي — الثقة رخيصة في هذه الحدود.

مثال (4-2.33): مضاعفة العيّنة مع تنظيم يحفظ $n\beta$ المعطيات: $\beta = 1/n$ (مثل حيد بـ $L = 1$ و $\lambda = 2$)؛ من $n = 1000$ إلى $n = 4000$، بـ $\delta = 0.05$ و $M = 1$. المطلوب: أثر مضاعفة البيانات أربع مرّات. الحل: الخطوة 1: عند $n = 1000$: $\beta = 0.001$ والحدّ 0.19550 (من المثال 1). الخطوة 2: عند $n = 4000$: $\beta = 0.00025$، $4n\beta = 4$، و $\sqrt{2.9957/8000} = 0.019351$، فـ $(5)(0.019351) = 0.09676$، و $2\beta = 0.0005$، المجموع 0.09726. الخطوة 3: النسبة $0.19550/0.09726 = 2.010$. النتيجة: مضاعفة n أربع مرّات حسّنت الحدّ بمعامل 2 — أي بـ $1/\sqrt{n}$. الربط بالذكاء الاصطناعي: هذا هو معدّل التعلّم المتوقّع في منحنيات التعلّم من الفصل 30.

مثال (5-2.33): الفجوة بالتوقّع مقابل الفجوة باحتمال عالٍ المعطيات: $n = 1000$، $\beta = 0.001$، $M = 1$، $\delta = 0.05$. المطلوب: المقارنة بين (3.33) و (2.33). الحل: الخطوة 1: الفجوة بالتوقّع $\beta = 0.001 \le$. الخطوة 2: الفجوة باحتمال عالٍ ≤ 0.19550. الخطوة 3: النسبة 195.5. النتيجة: الحدّ الكلاسيكي فضفاض جدّاً مقيساً على سلوك المتوسّط. الربط بالذكاء الاصطناعي: سبب رئيسي لكون حدود التعلّم «موجّهة» أكثر منها «كمّية».

مثال (6-2.33): قياس β تجريبيّاً المعطيات: خوارزمية مجهولة التحليل؛ أعدنا التدريب على S وعلى $S^{i,z}$ لعشر تبديلات، وقِسنا الخسارة على 200 نقطة حجز. المطلوب: تقدير β والحدّ. الحل: الخطوة 1: أعظم فرق ملاحظ $= 0.0018$، ومتوسطه $= 0.0004$. الخطوة 2: نأخذ $\hat{\beta} = 0.0018$ (متحفّظ، لأنّ التعريف بالسوبرميم). الخطوة 3: $2\beta = 0.0036$، $4n\beta = 7.2$ مع $n = 1000$، فـ $(8.2)(0.03870) = 0.31734$، المجموع 0.32094. النتيجة: تقدير

قابل للقياس المباشر — هذه ميزة الاستقرار على بُعد VC. الربط بالذكاء الاصطناعي: اختبارات «إعادة التدريب بتبديل نقطة» أداة عملية لتشخيص الحفظ.

مثال (33.2-7): أقرب الجيران واستقرار متوسط المعطيات: مصنّف NNk- على $n = 1000$، بخسارة 0-1. المطلوب: تقدير حساسية المثال الواحد عند $k = 5$ و $k = 1$. الحل: الخطوة 1: لا تتغيّر الخسارة على نقطة استعلام إلا إذا كانت النقطة المبدَّلة من بين الجيران الـ k. الخطوة 2: باحتمال على نقطة الاستعلام $\leq k/n$، أي $\beta \approx 0.005$ عند $k = 5$ و 0.001 عند $k = 1$. الخطوة 3: الحدّ عند $k = 5$: $2\beta = 0.01$، $4n\beta = 20$، $(21)(0.03870) = 0.81270$، المجموع 0.82270. النتيجة: الحدّ عند $k = 5$ شبه فارغ، ومع ذلك يعمل المصنّف جيّداً. الربط بالذكاء الاصطناعي: تذكير بأنّ حدود الاستقرار **كافية** للتعميم **لا ضرورية** له.

مثال (33.2-8): التجميع (bagging) يخفض الحساسية المعطيات: شجرة واحدة يتغيّر ناتجها بمقدار $\sigma_\delta = 0.2$ عند تبديل نقطة، $B = 100$ حزمة bootstrap بحجم n. المطلوب: حساسية المتوقّع المجمَّع. الحل: الخطوة 1: احتمال ظهور النقطة في حزمة bootstrap $1 - (1 - 1/n)^n \approx 1 - e^{-1} = 0.6321$. الخطوة 2: عدد الحزم المتأثّرة $\approx 0.6321B$، ووزنها في المتوسط $1/B$. الخطوة 3: الانحراف المعياري للفرق $= \sigma_\delta \sqrt{0.6321/B} = 0.2\sqrt{0.006321} = 0.2(0.07950) = 0.01590$. النتيجة: الحساسية هبطت من 0.2 إلى 0.0159، أي بنحو 12.6 مرّة. الربط بالذكاء الاصطناعي: هذا هو التفسير الكمّي لنجاح الغابات العشوائية: التجميع **منظّم استقرار**.

مثال (33.2-9): سقف الخسارة M يهمّ فعلاً المعطيات: إنتروبيا تقاطعية مقطوعة عند احتمال 10^{-3}؛ $n = 1000$، $\beta = 0.001$، $\delta = 0.05$. المطلوب: الحدّ ومقارنته بخسارة 0-1. الحل: الخطوة 1: $M = \ln(1000) = 6.9078$. الخطوة 2: $4n\beta + M = 4 + 6.9078 = 10.9078$، فـ $(10.9078)(0.03870) = 0.42213$. الخطوة 3: المجموع مع 2β: 0.42413 مقابل 0.19550 في حالة $M = 1$. النتيجة: اتّساع مدى الخسارة ضاعف الحدّ 2.17 مرّة. الربط بالذكاء الاصطناعي: سبب تفضيل خسائر محدودة أو مقطوعة عند الرغبة في ضمانات.

مثال (33.2-10): تشخيص طبي بعيّنة متوسّطة المعطيات: $n = 2000$ سجلّ مريض، خوارزمية انحدار لوجستي منظّم قيست حساسيتها $\beta = 0.0003$، $M = 1$، $\delta = 0.05$. المطلوب: هامش الثقة في خطر التعميم. الحل: الخطوة 1: $\sqrt{2.9957/4000} = 0.027367$. الخطوة 2: $4n\beta = 2.4$، فـ $(3.4)(0.027367) = 0.093048$. الخطوة 3: المجموع مع $2\beta = 0.0006$: 0.093648. النتيجة: نتوقّع ألّا يتجاوز خطأ التشغيل خطأ التدريب بـ 0.094. الربط بالذكاء الاصطناعي: رقمٌ قابل للعرض على لجنة أخلاقيات طبية، بعكس حدود السعة.

مثال (33.2-11): تسعير مالي بخسارة محدودة المدى المعطيات: خسارة = مقدار خطأ العائد، محدودة بـ $M = 0.05$؛ $n = 5000$، $\beta = 0.00005$، $\delta = 0.05$. المطلوب: الحدّ بوحدات النسبة المئوية. الحل: الخطوة 1: $\sqrt{2.9957/10000} = 0.017308$. الخطوة 2: $4n\beta = 1$، فـ $(1.05)(0.017308) = 0.018173$. الخطوة 3: المجموع 0.018273، أي 0.0183 من العائد المطلق. النتيجة: هامش يعادل 1.83 نقطة مئوية من سقف الخسارة. الربط بالذكاء الاصطناعي: في المالية، M الصغير يعوّض جزئيّاً عن استقرار ضعيف.

مثال (33.2-12): سياسة روبوت غير مستقرّة المعطيات: $n = 500$ مسار، خوارزمية تحكم بأقرب الجيران، $\beta = 0.02$، $M = 1$. المطلوب: هل الحدّ مفيد؟ الحل: الخطوة 1: $\sqrt{2.9957/1000} = 0.054734$. الخطوة 2: $4n\beta = 40$، فـ $(41)(0.054734) = 2.24409$، والمجموع 2.28409. الخطوة 3: الحدّ أكبر من $M = 1 \Rightarrow$ فارغ تماماً. النتيجة: نشترط $\beta \lesssim 1/(4n) = 0.0005$ لحدٍّ غير فارغ. الربط بالذكاء الاصطناعي: في الروبوتات، قلّة البيانات مع خوارزميات عالية التباين تقتل أيّ ضمان.

مثال (33.2-13): كشف تسلّل شبكي بعيّنة صغيرة المعطيات: $n = 200$ تدفّق، $\beta = 0.004$، $M = 1$، $\delta = 0.05$. المطلوب: الحدّ. الحل: الخطوة 1: $\sqrt{2.9957/400} = 0.086539$. الخطوة 2: $4n\beta = 3.2$، فـ

$0.363464 = (4.2)(0.086539)$. الخطوة 3: المجموع مع $2\beta = 0.008$: 0.371464. النتيجة: الحدّ يستوعب نحو ثلث مدى الخسارة — ضعيف لكن قابل للتحسين بزيادة n. الربط بالذكاء الاصطناعي: مع $n = 2000$ يصير الحدّ $(3.2+1)(0.027367) + 0.0008 = 0.11574$.

مثال (14-2.33): فضاء فرضيات واحد وخوارزمتان المعطيات: $\mathcal{H}$ خطّي في $\mathbb{R}^{1000}$، $n = 1000$؛ الخوارزمية الأولى ERM خام بـ $\beta \approx 0.5$، والثانية حيد بـ $\beta = 0.002$. المطلوب: ماذا تقول كلّ من المنهجيتين؟ الحل: الخطوة 1: حدّ السعة واحد للاثنتين (نفس $\mathcal{H}$)، وبصيغة $\sqrt{d/n} = \sqrt{1000/1000} = 1 \Rightarrow$ فارغ. الخطوة 2: ERM خام: $4n\beta = 2000$، فـ $(2001)(0.03870) = 77.44 \Rightarrow$ فارغ جدّاً. الخطوة 3: الحيد: $4n\beta = 8$، فـ $(9)(0.03870) = 0.34830$، المجموع 0.35230. النتيجة: الاستقرار يميّز بين خوارزميتين لا يميّز بينهما بُعد VC. الربط بالذكاء الاصطناعي: الجواب النظري الأول على سؤال «لماذا يعمل التنظيم؟».

مثال (15-2.33): الكمية الحاكمة $n\beta$ المعطيات: أزواج (n, β): $(1000, 0.001)$، $(1000, 0.0002)$، $(10000, 0.0001)$، $(100, 0.01)$، $(500, 0.02)$. المطلوب: ترتيب الحدود من الأفضل إلى الأسوأ. الحل: الخطوة 1: احسب $n\beta$: 1، 0.2، 1، 1، 10. الخطوة 2: القاعدة: الحدّ $(4n\beta + M)\sqrt{\ln(1/\delta)/(2n)} \approx$، فيتضخّم خطّيّاً مع $n\beta$. الخطوة 3: الترتيب: $(1000, 0.0002)$ أفضل، ثمّ الثلاثة ذات $n\beta = 1$، ثمّ $(500, 0.02)$. النتيجة: شرط عدم الفراغ: $\beta = O(1/n)$. الربط بالذكاء الاصطناعي: معيار تصميم عملي: صمّم الخوارزمية بحيث تتضاءل حساسيتها للمثال الواحد بسرعة $1/n$.

أخطاء شائعة

- الخلط بين استقرار الخوارزمية وثباتها العددي (conditioning) — الأوّل عن البيانات، والثاني عن الحساب.
- ظنّ أنّ β صغير يعني بالضرورة خطأ تعميم صغير: الحدود **كافية** لا **ضرورية**.
- تجاهل سقف الخسارة M: خسارة غير محدودة تُبطل (2.33) رسميّاً.
- تطبيق التعريف على التغيّر في **الفرضية** بدل التغيّر في **الخسارة** (اختلاف β_h عن β_e).
- نسيان أنّ (1.33) سوبرميم على كلّ العيّنات: تقدير β من عيّنة واحدة متفائل.
- افتراض أنّ الحدّ ينتقي معلمات فائقة: هو يتدهور رتيباً مع β، أمّا التحيز فيزداد، فلا بدّ من موازنة (الفصل 30).

المبرهنة (استقرار ERM المنظّم تنظيماً قويّاً): ليكن فضاء المعلمات محدّباً مغلقاً، ولتكن الخسارة $\ell(\cdot, z)$ محدّبة و L-لبشيتزية في w لكلّ z. عرّف خوارزمية التنظيم القوي

$$A(S) = \arg\min_{w} F_S(w), \qquad F_S(w) = \frac{1}{n}\sum_{i=1}^{n} \ell(w, z_i) + \frac{\lambda}{2}\|w\|^2 \tag{4.33}$$

فـ F_S محدّبة بقوّة بثابت λ، و A مستقرّة توحيديّاً بـ

$$\|A(S) - A(S^{i,z})\| \le \frac{2L}{\lambda n} \tag{5.33}$$

$$\beta \;\le\; \frac{2L^2}{\lambda n} \tag{6.33}$$

وبالتعويض في (2.33)، لكلّ $\delta \in (0,1)$ وباحتمال $\ge 1-\delta$:

$$R\big(A(S)\big) \;\le\; \hat{R}_S\big(A(S)\big) \;+\; \frac{4L^2}{\lambda n} \;+\; \Big(\frac{8L^2}{\lambda} + M\Big)\sqrt{\frac{\ln(1/\delta)}{2n}} \tag{7.33}$$

وعكس العلاقة يعطي قاعدة تصميم: لبلوغ استقرار β مستهدف يكفي اختيار

$$\lambda \;\ge\; \frac{2L^2}{\beta\, n} \tag{8.33}$$

ملاحظة على الثوابت:

تختلف الثوابت بين المراجع ($\frac{L^2}{\lambda n}$ أو $\frac{2L^2}{\lambda n}$ أو $\frac{4L^2}{\lambda n}$) بحسب صيغة المؤثّر المنتظم — $\lambda\|w\|^2$ أم $\frac{\lambda}{2}\|w\|^2$ — وبحسب استخدام لبشيتزية الخسارة أم لبشيتزية تدرّجها. الصيغة (6.33) هي الشائعة مع التنظيم $\frac{\lambda}{2}\|w\|^2$.

جدول الرموز

الرمز	المعنى	ملاحظة
λ	قوّة التنظيم = ثابت التحدّب القوي	كلّما كبر صغر β
L	ثابت لبشيتز: $\|\ell(w,z)-\ell(w',z)\| \le L\|w-w'\|$	يظهر مربّعاً
$2L/(\lambda n)$	بعد المعلَمَين المخرجين من عيّنتين متجاورتين	(5.33)
$8L^2/\lambda$	بديل $4n\beta$ في (2.33)	لا يعتمد على n
$4L^2/(\lambda n)$	بديل 2β	يتضاءل بـ $1/n$

الرسم

<figure> الشكل<figcaption> 2.33: التحدّب القوي يجعل قاع الهدف حادّاً، فلا تتحرّك النقطة الصغرى إلا بمقدار $2L/(\lambda n)$ حين يستبدل مثالٌ واحد.</figcaption/> </figure>

البرهان

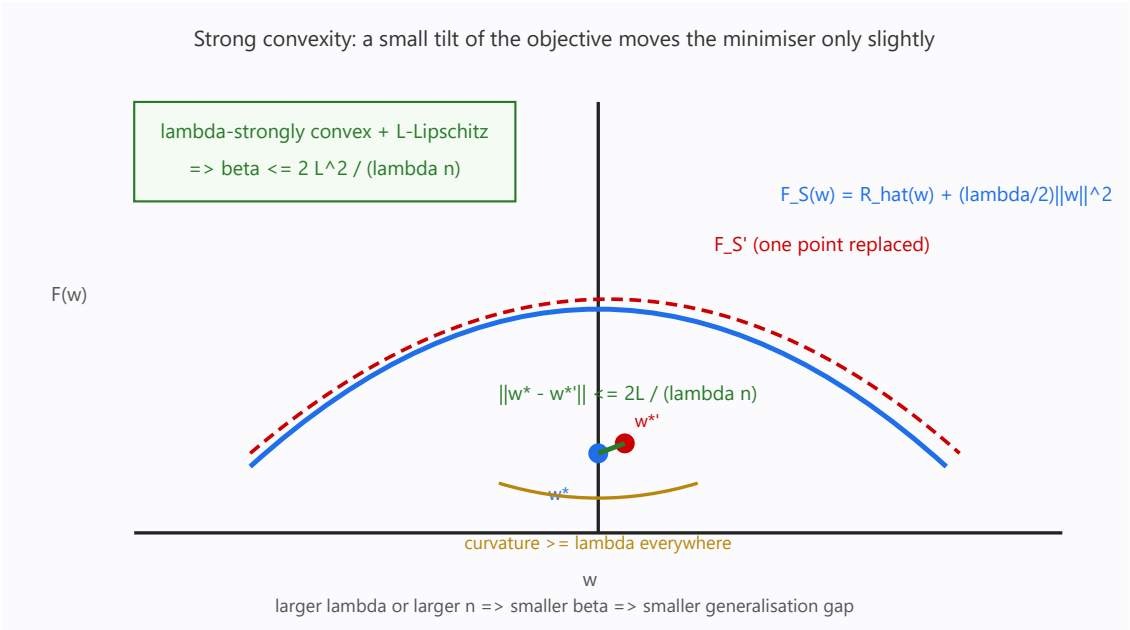
الخطوة 1 (التحدّب القوي): المجموع المحدّب مضافاً إليه $\frac{\lambda}{2}\|w\|^2$ يعطي هدفاً λ-محدّباً بقوّة. وبما أنّ $\nabla F_S(w) = 0$ فإنّ

$$F_S(w') - F_S(w) \ge \frac{\lambda}{2}\|w-w'\|^2, \qquad F_{S'}(w) - F_{S'}(w') \ge \frac{\lambda}{2}\|w-w'\|^2$$

الخطوة 2 (الجمع وإلغاء الحدود المشتركة): بما أنّ $F_{S'}(g) - F_S(g) = \frac{1}{n}[\ell(g,z) - \ell(g,z_i)]$، فبجمع المتراجحتين يبقى

$$\lambda\|w-w'\|^2 \;\le\; \frac{1}{n}\Big[\ell(w,z) - \ell(w,z_i) + \ell(w',z_i) - \ell(w',z)\Big]$$

الخطوة 3 (لبشيتزية): كلّ فرق بين قوسين محدود بـ $L\|w-w'\|$، فـ $\lambda\|w-w'\|^2 \le \frac{2L}{n}\|w-w'\|$، أي $\|w-w'\| \le \frac{2L}{\lambda n}$، وهو (5.33). ■



شكل ٢٠٣٣: *
التحدب القوي يقيد حركة النقطة الصغرى عند تبديل مثال واحد

الخطوة 4 (من الفرضية إلى الخسارة): $|\ell(w,z')-\ell(w',z')| \le L\|w-w'\| \le \frac{2L^2}{\lambda n}$ لكلّ z'، وهو (6.33)؛ والتعويض المباشر في (2.33) يعطي (7.33). ■

الخطوة 5 (القراءة): $4n\beta = 8L^2/\lambda$ لا يعتمد على n، فمعدّل تقارب الفجوة هو $1/\sqrt{n}$ بمعامل يناسب L^2/λ، في حين يتضاءل الجزء $4L^2/(\lambda n)$ بسرعة $1/n$. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.33): حيد على خصائص رؤية حاسوبية المعطيات: انحدار حيد، $L = 1$، $\lambda = 0.5$، $n = 2000$. المطلوب: سقف الاستقرار وبُعد المعلمَين. الحل: الخطوة 1: $2/1000 = 0.002$. الخطوة 2: $\beta \le 2(1)^2/(0.5\cdot 2000) = 2/1000 = 0.002$. الخطوة 3: الفجوة بالتوقّع $\le \beta = 0.002$. النتيجة: $\|w-w'\| \le 2L/(\lambda n) = 2/1000 = 0.002$. الخطوة 4: الخوارزمية لا تتأثّر بالمثال الواحد إلا بمقدار 0.002 من مدى الخسارة. الربط بالذكاء الاصطناعي: هذا هو المعنى الكمّي لعبارة «التنظيم يمنع الحفظ».

مثال (2-3.33): تخفيف التنظيم إلى النصف المعطيات: نفس الإعدادات لكن $\lambda = 0.25$. المطلوب: الاستقرار الجديد. الحل: الخطوة 1: $2/(0.25\cdot 2000) = 2/500 = 0.004$. الخطوة 2: النسبة إلى السابق: $0.004/0.002 = 2$. النتيجة: β يتناسب عكسياً مع λ تماماً. الربط بالذكاء الاصطناعي: كلّ تخفيف للتنظيم يُترجم مباشرةً إلى ضعف في الضمان.

مثال (3-3.33): مضاعفة البيانات المعطيات: $L = 1$، $\lambda = 0.5$، من $n = 2000$ إلى $n = 4000$. المطلوب: الاستقرار الجديد. الحل: الخطوة 1: $2/(0.5\cdot 4000) = 2/2000 = 0.001$. الخطوة 2: نصف القيمة السابقة. النتيجة: β يتناسب عكسياً مع n كذلك. الربط بالذكاء الاصطناعي: البيانات الكثيرة تجعل المثال الواحد أقلّ وزناً — بديهيةٌ صارت مبرهنة.

مثال (4-3.33): آلة المتجهات الداعمة وثابت لبشيتز من مدى المُدخلات المعطيات: خسارة المفصلة $\ell = \max(0, 1 - y\,w^\top x)$، و $R = 5$، $\|x\| \le 1$، $\lambda = 1000$، $n = 4000$. المطلوب: L ثمّ β ثمّ الحدّ. الحل: الخطوة 1: تدرّج الخسارة في w هو $-y\,x$ داخل المنطقة النشطة، فـ $L = R = 5$. الخطوة 2:

$\beta \le 2(25)/(1\cdot 1000) = 50/1000 = 0.05$. الخطوة 3: $4n\beta = 200$، فـ $(201)(0.03870) = 7.779$ $\Rightarrow$ الحدّ فارغ. النتيجة: تطبيع المُدخلات خطوةٌ نظرية قبل أن تكون هندسية. الربط بالذكاء الاصطناعي: لهذا تُوحَّد الخصائص قبل تدريب SVM. تصغير R يربّع الفائدة.

مثال (33.3-5): SVM على تدفّقات شبكية المعطيات: الخصائص موحّدة فصار $R = 1$، $\lambda = 0.01$، $n = 20000$. المطلوب: β والحدّ الكامل عند $\delta = 0.05$ و $M = 1$. الحل: الخطوة 1: $L = 1$، فـ $\beta \le 2/(0.01\cdot 20000) = 2/200 = 0.01$. الخطوة 2: $\sqrt{2.9957/40000} = 0.008654$. الخطوة 3: $4n\beta = 800$، $2\beta = 0.02$، فالحدّ $(801)(0.008654) + 0.02 = 6.933$ $\Rightarrow$ فارغ. النتيجة: λ صغير مع n كبير لا يكفي؛ المهمّ L^2/λ. الربط بالذكاء الاصطناعي: الشائع في الممارسة $\lambda \sim 1/n$، وهذا يجعل $4n\beta$ ثابتاً لا متضائلاً.

مثال (33.3-6): حيد نَوويّ على بيانات مالية المعطيات: $\lambda = 2$، $n = 5000$، $L = 1$، $M = 1$، $\delta = 0.05$. المطلوب: الحدّ الكامل. الحل: الخطوة 1: $\beta \le 2/(2\cdot 5000) = 0.0002$. الخطوة 2: $4n\beta = 4$، $2\beta = 0.0004$، و $\sqrt{2.9957/10000} = 0.017308$. الخطوة 3: الحدّ $(5)(0.017308) + 0.0004 = 0.08694$. النتيجة: فجوة تعميم مضمونة دون 0.087. الربط بالذكاء الاصطناعي: في التنبؤ المالي، هامش 8.7% على مدى الخسارة حدٌّ مقبول للتصميم.

مثال (33.3-7): الشبكة المرنة (elastic net) في تعلّم آلة صناعي المعطيات: عقاب $\mu\|w\|_1 + \frac{\lambda}{2}\|w\|^2$ بـ $\lambda = 0.1$، و $L = 3$، $n = 5000$. المطلوب: هل تنطبق المبرهنة؟ ثمّ β. الحل: الخطوة 1: $\|w\|_1$ محدّب لكن غير محدّب بقوّة، أمّا $\frac{\lambda}{2}\|w\|^2$ فيضمن التحدّب القوي. الخطوة 2: F_S إذن λ-محدّبة بقوّة والمبرهنة تنطبق. الخطوة 3: $\beta \le 2(9)/(0.1\cdot 5000) = 18/500 = 0.036$. النتيجة: التناثر من الحدّ الأول لا يضرّ الاستقرار ما دام الحدّ التربيعي حاضراً. الربط بالذكاء الاصطناعي: لماذا تُفضَّل الشبكة المرنة على Lasso وحدها عند الرغبة في ضمان.

مثال (33.3-8): اختيار λ لبلوغ استقرار مستهدف المعطيات: $L = 2$، $n = 1000$، المطلوب $\beta \le 0.001$. المطلوب: أصغر λ يحقّق ذلك. الحل: الخطوة 1: من (33.8): $\lambda \ge 2L^2/(\beta n)$. الخطوة 2: $\lambda \ge 2(4)/(0.001\cdot 1000) = 8/1 = 8$. الخطوة 3: تحقّق: $\beta = 2(4)/(8\cdot 1000) = 8/8000 = 0.001$ ✓. النتيجة: $\lambda = 8$ — قيمة كبيرة لكنّها مطلوبة مع $L = 2$. الربط بالذكاء الاصطناعي: معيار قابل للحساب المسبق بدل البحث الشبكي الأعمى.

مثال (33.3-9): الحدّ الكامل دالّة في λ — لماذا لا ينتقي الحدّ وحده؟ المعطيات: $L = 1$، $M = 1$، $n = 1000$، $\delta = 0.05$ (أي $\sqrt{\cdot} = 0.03870$). المطلوب: رسم الحدّ مقابل λ. الحل: الخطوة 1: الحدّ $= \frac{4}{1000\lambda} + (0.03870)(1 + \frac{8}{\lambda})$. الخطوة 2: $\lambda = 0.1$: $3.175 = (81)(0.03870) + 0.04$ (فارغ). الخطوة 3: $\lambda = 1$: $0.35230 = (9)(0.03870) + 0.004$. الخطوة 4: $\lambda = 10$: $0.07006 = (1.8)(0.03870) + 0.0004$. الخطوة 5: $\lambda = 100$: $0.04184 = (1.08)(0.03870) + 0.00004$. النتيجة: الحدّ **متناقص رتيب** في λ ولا يختار قيمة مثلى. الربط بالذكاء الاصطناعي: لا بدّ من ضمّ $\hat{R}_S$ إلى الحدّ كما في SRM (الفصل 30)؛ التحيز يرتفع مع λ فيوازن.

مثال (33.3-10): انحدار لوجستي طبي المعطيات: 800 مريض، خصائص موحّدة بـ $\|x\| \le 3$، $\lambda = 4$. المطلوب: L ثمّ β. الحل: الخطوة 1: تدرّج الخسارة اللوجستية $(\sigma(w^\top x) - y)x$ معياره $\le 3 \le \|x\|$، فـ $L = 3$. الخطوة 2: $\beta \le 2(9)/(4\cdot 800) = 18/3200 = 0.005625$. الخطوة 3: $\|w - w'\| \le 2(3)/(4\cdot 800) = 6/3200 = 0.001875$. النتيجة: استقرار جيّد رغم صغر العيّنة، بفضل λ كبير. الربط بالذكاء الاصطناعي: في الطبّ حيث n صغير، التنظيم القوي ليس ترفاً بل ضرورة نظرية.

مثال (33.3-11): خسارة هوبَر المقاوِمة في التنبؤ المالي المعطيات: خسارة Huber بمعلَم $\delta_H = 1.5$، فتدرّجها مقطوع ولبشيتزي بـ $L = 1.5$؛ $\lambda = 0.2$، $n = 10000$. المطلوب: β. الحل: الخطوة 1: $\beta \le 2(2.25)/(0.2\cdot 10000) = 4.5/2000 = 0.00225$. الخطوة 2: قارن بخسارة تربيعية غير مقطوعة حيث L ينمو مع الخطأ ولا يوجد سقف. النتيجة: قصّ التدرّج يمنح لبشيتزية مجّانية $\Rightarrow$ استقراراً مجّانيّاً. الربط بالذكاء

الاصطناعي: الفكرة نفسها ستظهر في قصّ التدرّج داخل DP-SGD (النظرية 7.33).

مثال (12-3.33): حيد نَوويّ واسع النطاق في الرؤية المعطيات: $\lambda = 0.01$، $n = 50000$، $L = 1$. المطلوب: β وحكم على الحدّ عند $\delta = 0.05$. الحل: الخطوة 1: $\beta \le 2/(0.01 \cdot 50000) = 2/500 = 0.004$. الخطوة 2: $4n\beta = 800$، $2\beta = 0.008$، و $\sqrt{2.9957/100000} = 0.005473$. الخطوة 3: الحدّ $= 0.008 + (801)(0.005473) = 4.392 \Rightarrow$ فارغ. النتيجة: الحجم الكبير للعيّنة لا يعوّض عن λ الصغير؛ الحاكم هو L^2/λ. الربط بالذكاء الاصطناعي: درس تصميم: وحّد الخصائص (صغّر L) قبل أن تكبّر n.

مثال (13-3.33): SVM لتصنيف نصوص عربية المعطيات: تمثيل tf-idf موحّد بالمعيار الثاني، أي $\|x\| = 1$، $\lambda = 0.01$، $n = 20000$. المطلوب: β. الحل: الخطوة 1: $L = R = 1$، فـ $\beta \le 2/(0.01 \cdot 20000) = 0.01$. الخطوة 2: لو لم تُوحَّد المتجهات فستبلغ $R \approx 20$، فيصير $\beta \le 2(400)/200 = 4$. الخطوة 3: الفرق بين الحالتين معامل 400. النتيجة: التوحيد يعطي تحسّناً بـ 400 ضعف في سقف الاستقرار. الربط بالذكاء الاصطناعي: أكبر مكسب نظري مقابل أرخص خطوة هندسية في معالجة النصوص.

مثال (14-3.33): سياسة روبوت بحيد على مسارات قليلة المعطيات: $\lambda = 5$، $n = 300$، $L = 4$. المطلوب: β. الحل: الخطوة 1: $\beta \le 2(16)/(5 \cdot 300) = 32/1500 = 0.021333$. الخطوة 2: لو تُرك $\lambda = 0.5$ لصار $\beta = 32/150 = 0.213333$. النتيجة: مع n صغير، رفع λ عشر مرّات أنقذ الحدّ من الفراغ النسبي. الربط بالذكاء الاصطناعي: في التعلّم الروبوتي حيث المسارات غالية، التنظيم بديلٌ عن البيانات.

مثال (15-3.33): جدول مقارنة سريع المعطيات: أربعة إعدادات: $(L, \lambda, n) = (1, 2, 1000)$، $(1, 0.5, 2000)$، $(3, 4, 800)$، $(5, 1, 1000)$. المطلوب: حساب β وترتيبها. الحل: الخطوة 1: $2/(2 \cdot 1000) = 0.001$. الخطوة 2: $2/(0.5 \cdot 2000) = 0.002$. الخطوة 3: $18/3200 = 0.005625$. الخطوة 4: $50/1000 = 0.05$. الخطوة 5: الترتيب: $0.001 < 0.002 < 0.005625 < 0.05$. النتيجة: $L^2/\lambda n$ هو كلّ ما يلزم حفظه من هذه النظرية. الربط بالذكاء الاصطناعي: قاعدة إبهام: ضاعف λ أو ضاعف n لتنصيف β؛ وربع L لربح أربعة أضعاف.

أخطاء شائعة

- تطبيق المبرهنة على شبكة عميقة بدعوى أنّ فيها تنظيماً: الشبكة **غير محدّبة**، فالتحدّب القوي مفقود تماماً.
- الخلط بين $\lambda\|w\|^2$ و $\frac{\lambda}{2}\|w\|^2$ ثمّ مقارنة الثوابت بين المراجع.
- حساب L من الخسارة وحدها ونسيان أنّه يضرب مدى المُدخلات: $L_{\text{خسارة}} \cdot \sup\|x\| \approx L_{\text{فعلي}}$.
- الاعتقاد بأنّ وجود λ صغير كافٍ؛ الحاكم هو L^2/λ لا λ وحده.
- استخدام الحدّ وحده لانتقاء λ (متناقص رتيب) بدل جمعه مع الخطر التجريبي.
- افتراض أنّ التنظيم يقلّل الخطأ دائماً: هو يقلّل **الفجوة** وقد يرفع التحيز.

الإطار: ليكن A_{SGD} هبوط التدرّج العشوائي بمؤشّرٍ موحّد $i_t \sim \mathcal{U}\{1, \dots, n\}$ في كلّ خطوة:

$$w_{t+1} = \Pi_{\mathcal{W}}\Big(w_t - \alpha_t \nabla_w \ell(w_t; z_{i_t})\Big), \qquad t = 1, \dots, T \tag{9.33}$$

حيث $\mathcal{W}$ محدّبة مغلقة و Π إسقاطٌ غير موسِّع. نفترض:

(10.33)
$$\|\nabla \ell(w;z) - \nabla \ell(w';z)\| \le \gamma \|w - w'\| \quad \text{(نعومة)}, \qquad \|\nabla \ell(w;z)\| \le L \quad \text{(لبشيتزية الخسارة)}$$

المبرهنة (الحالة المحدّبة الملساء): إذا كانت $\ell(\cdot;z)$ محدّبة وناعمة بـ γ لكلّ z، و $\alpha_t \le 2/\gamma$، فإنّ A_{SGD} مستقرّ توحيديّاً بـ

$$\beta \;\le\; \frac{2L^2}{n} \sum_{t=1}^{T} \alpha_t \tag{11.33}$$

وبالتالي، باحتمال $\ge 1-\delta$،

$$R(A(S)) \;\le\; \hat{R}_S(A(S)) \;+\; \frac{4L^2}{n}\sum_{t=1}^{T}\alpha_t \;+\; \Big(8L^2 \sum_{t=1}^{T}\alpha_t + M\Big)\sqrt{\frac{\ln(1/\delta)}{2n}} \tag{12.33}$$

المبرهنة (الحالة غير المحدّبة): بلا افتراض التحدّب، يحلّ عامل التوسّع $(1+\alpha_t\gamma)$ محلّ عدم التوسّع، فنحصل على

$$\alpha_t = \alpha \text{ ثابت:} \qquad \beta \;\le\; \frac{2L^2}{n\gamma}\Big[(1+\alpha\gamma)^{T} - 1\Big] \tag{13.33}$$

$$\alpha_t = \frac{c}{t} \text{ متضائل:} \qquad \beta \;\le\; \frac{2L^2}{n\gamma}\Big[T^{c\gamma} - 1\Big] \tag{14.33}$$

النتيجة المفاهيمية: الحدّ (11.33) **خالٍ من عدد المعلمات** p، وينمو مع عدد الخطوات T. ومن هنا: التوقّف المبكر وتضاؤل معدّل الخطوة ليسا حيلتين تجريبيتين بل شرطان لضمان التعميم.

جدول الرموز

الرمز	المعنى	ملاحظة
α_t	معدّل الخطوة	من الفصل 23
γ	ثابت نعومة التدرّج	يظهر في الأسّ في (13.33)
T	عدد الخطوات الكلّي	$= n/b \times$ عدد الدورات
$\delta_t = \|w_t - w'_t\|$	تباعد مسارين على عيّنتين متجاورتين	المتغيّر المحوري في البرهان
c	ثابت التضاؤل في $\alpha_t = c/t$	مرغوب $c\gamma < 1$

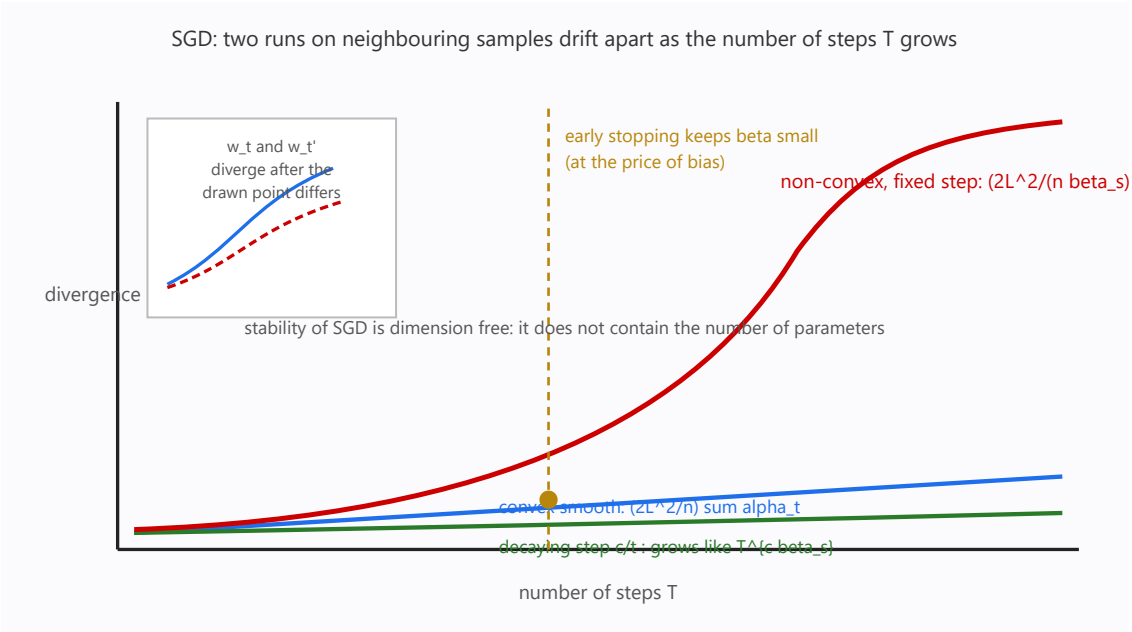
الرسم

<figure> الشكل<figcaption> 3.33: مساران لهبوط التدرّج على عيّنتين تختلفان في مثال واحد: التباعد ينمو مع T خطّيّاً في الحالة المحدّبة وأسيّاً في غير المحدّبة بخطوة ثابتة.</figcaption> </figure>

البرهان

الخطوة 1 (الاقتران): نشغّل الخوارزمية على S و S' بمتتالية المؤشّرات نفسها (جائز لأنّ توزيعها لا يعتمد على البيانات)، ونرمز $\delta_t = \|w_t - w'_t\|$ مع $\delta_0 = 0$.

الخطوة 2 (الحالتان): إن كان $i_t \neq i$ فالتدرّجان من النقطة نفسها، فبنعومة التدرّج $\delta_{t+1} \le (1+\alpha_t\gamma)\delta_t$؛ وإن كان $i_t = i$ فبمثلّث التفاوت $\|\nabla \ell(w_t;z_i) - \nabla \ell(w'_t;z)\| \le 2L + \gamma\delta_t$، فـ $\delta_{t+1} \le (1+\alpha_t\gamma)\delta_t + 2\alpha_t L$.



شكل ٣٣.٣: *
تباعد مساري هبوط التدرج العشوائي مع عدد الخطوات

الخطوة 3 (التوقّع): بالجمع على الاحتمالين $1/n$ و $1-1/n$:

$$\mathbb{E}[\delta_{t+1}] \;\le\; (1+\alpha_t\gamma)\,\mathbb{E}[\delta_t] \;+\; \frac{2\alpha_t L}{n} \tag{15.33}$$

الخطوة 4 (الحالة المحدّبة الملساء): لخسارة محدّبة ناعمة و $\alpha_t \le 2/\gamma$ تكون مؤثّرة التدرّج غير موسّعة، فيسقط عامل $(1+\alpha_t\gamma)$ ويبقى $\mathbb{E}[\delta_T] \le \frac{2L}{n}\sum_t \alpha_t$؛ وبلبشيتزية الخسارة $\beta \le L\,\mathbb{E}[\delta_T]$ ينتج (11.33). ■

الخطوة 5 (الحالة غير المحدّبة): نحلّ (15.33) تكرارياً بـ $\delta_0 = 0$. بخطوة ثابتة α: $\mathbb{E}[\delta_T] \le \frac{2\alpha L}{n}\sum_{k<T}(1+\alpha\gamma)^k = \frac{2L}{n\gamma}[(1+\alpha\gamma)^T - 1]$. وبخطوة $\alpha_t = c/t$، يُستعاض عن الجداء بـ $(T/t)^{c\gamma}$ فـ $\mathbb{E}[\delta_T] \le \frac{2L}{n\gamma}[T^{c\gamma}-1]$. والضرب في L يعطي (13.33) و (14.33). ■

الخطوة 6 (القراءة): الحدّ خطّيّ في $\sum_t \alpha_t$ في الحالة المحدّبة، وأسيّ في T في غير المحدّبة بخطوة ثابتة، والتضاؤل يحيله إلى كثيرة حدود $T^{c\gamma}$. ولا يظهر p في أيّ موضع. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.33): هبوط تدرّج عشوائي بخطوة ثابتة المعطيات: $L=1$، $\alpha=0.1$، $T=1000$، $n=5000$، خسارة محدّبة ملساء. المطلوب: β وفجوة التعميم. الحل: الخطوة 1: $\sum_t \alpha_t = 0.1\times 1000 = 100$. الخطوة 2: $\beta \le 2(1)^2(100)/5000 = 200/5000 = 0.04$. الخطوة 3: الفجوة بالتوقّع $\le \beta = 0.04$. النتيجة: أثر كلّ مثال على المخرَج محدود بـ 4% من مدى الخسارة. الربط بالذكاء الاصطناعي: رقمٌ معقول لخوارزمية تمرّ مرّتين على بيانات متوسّطة الحجم.

مثال (2-4.33): التوقّف المبكر ينصّف الحدّ المعطيات: الإعدادات نفسها لكن $T=500$. المطلوب: β الجديد. الحل: الخطوة 1: $\sum_t \alpha_t = 50$. الخطوة 2: $\beta \le 100/5000 = 0.02$. الخطوة 3: النسبة $0.04/0.02 = 2$. النتيجة: التوقّف عند نصف الخطوات ينصّف سقف الفجوة تماماً. الربط بالذكاء الاصطناعي: التوقّف المبكر مُنظِّم — هذه هي

الصيغة الرياضية للعبارة.

مثال (33.4-3): خطوة متضائلة أفضل بكثير المعطيات: $\alpha_t = 1/t$، $T = 1000$، $n = 5000$، $L = 1$. المطلوب: β ومقارنته بالخطوة الثابتة. الحل: الخطوة 1: $\sum_{t=1}^{1000} 1/t = H_{1000} \approx \ln(1000) + 0.5772 = 6.9078 + 0.5772 = 7.4850$. الخطوة 2: $\beta \le 2(7.4850)/5000 = 14.970/5000 = 0.002994$. الخطوة 3: النسبة إلى المثال 1: $0.04/0.002994 = 13.36$. النتيجة: التضاؤل وفّر معامل 13.4 في الاستقرار بلا تكلفة إضافية. الربط بالذكاء الاصطناعي: سبب نظرية لجدولة معدّل التعلّم المتضائلة في كلّ الممارسات الناجحة.

مثال (33.4-4): أثر حجم العيّنة المعطيات: الإعدادات نفسها في المثال 1 لكن $n = 50000$. المطلوب: β. الحل: الخطوة 1: $\beta \le 2(100)/50000 = 200/50000 = 0.004$. الخطوة 2: عُشر القيمة عند $n = 5000$. النتيجة: الاستقرار يتحسّن خطّيّاً مع n عند تثبيت T. الربط بالذكاء الاصطناعي: مع ثبات عدد الدورات يرتفع T مع n، فيبقى T/n ثابتاً — فائدة البيانات تظهر عند تثبيت الميزانية لا الدورات.

مثال (33.4-5): غير محدّبة بخطوة ثابتة — انفجار المعطيات: شبكة عصبية، $L = 1$، $\gamma = 1$، $\alpha = 0.1$، $T = 100$، $n = 5000$. المطلوب: β من (13.33). الحل: الخطوة 1: $(1+\alpha\gamma)^T = (1.1)^{100} = e^{100 \ln 1.1} = e^{9.5310} = 13781$. الخطوة 2: $\beta \le \frac{2}{5000 \cdot 1}(13781 - 1) = 0.0004 \times 13780 = 5.512$. الخطوة 3: القيمة أكبر من مدى الخسارة $\Rightarrow$ الحدّ فارغ تماماً. النتيجة: بخطوة ثابتة و T كبير، لا ضمان على الإطلاق. الربط بالذكاء الاصطناعي: تفسير مباشر لضرورة تضاؤل معدّل التعلّم في تدريب الشبكات العميقة.

مثال (33.4-6): غير محدّبة بخطوة c/t المعطيات: $c = 0.5$، $\gamma = 1$، $T = 1000$، $n = 5000$، $L = 1$. المطلوب: β من (14.33). الحل: الخطوة 1: $T^{c\gamma} = 1000^{0.5} = 31.623$. الخطوة 2: $\beta \le \frac{2}{5000}(31.623 - 1) = 0.0004 \times 30.623 = 0.012249$. النتيجة: من 5.5 الفارغة إلى 0.0122 المفيدة بمجرّد تضاؤل الخطوة. الربط بالذكاء الاصطناعي: الجدولة أهمّ من قيمة معدّل التعلّم الابتدائي ذاتها.

مثال (33.4-7): تضاؤل أسرع المعطيات: $c = 0.1$، $\gamma = 1$، $T = 1000$، $n = 5000$. المطلوب: β. الحل: الخطوة 1: $T^{c\gamma} = 1000^{0.1} = 10^{0.3} = 1.9953$. الخطوة 2: $\beta \le 0.0004(1.9953 - 1) = 0.0004 \times 0.9953 = 0.000398$. النتيجة: استقرار ممتاز، لكنّ التقدّم سيكون بطيئاً (تحيز مرتفع). الربط بالذكاء الاصطناعي: المقايضة الحتمية: استقرار أفضل مقابل تقارب أبطأ.

مثال (33.4-8): $c = 1$ مقابل $c = 0.1$ المعطيات: $c = 1$، $\gamma = 1$، $T = 1000$، $n = 5000$. المطلوب: β والفرق عن المثال 7. الحل: الخطوة 1: $T^1 = 1000$. الخطوة 2: $\beta \le 0.0004(999) = 0.3996$. الخطوة 3: النسبة إلى $c = 0.1$: $0.3996/0.000398 = 1004$. النتيجة: الأسّ $c\gamma$ حاكم بشكل مذهل. الربط بالذكاء الاصطناعي: قاعدة عملية: اجعل $c\gamma < 1$؛ أيّ α_t يبدأ من قيمة أقلّ من $1/\gamma$.

مثال (33.4-9): من الدورات إلى الخطوات المعطيات: $n = 5000$، حجم دفعة $b = 50$، $\alpha = 0.05$، 20 دورة. المطلوب: T ثمّ β. الحل: الخطوة 1: خطوات الدورة $= 5000/50 = 100$، فـ $T = 20 \times 100 = 2000$. الخطوة 2: $\sum \alpha_t = 0.05 \times 2000 = 100$. الخطوة 3: $\beta \le 2(100)/5000 = 0.04$. الخطوة 4: عند 5 دورات: $T = 500$ و $\sum \alpha_t = 25$، فـ $\beta \le 0.01$. النتيجة: عدد الدورات يترجم مباشرةً إلى ميزانية استقرار. الربط بالذكاء الاصطناعي: «كم دورة نُدرّب؟» سؤال استقرار قبل أن يكون سؤال تقارب.

مثال (33.4-10): حجم الدفعة وتقلّب الاضطراب المعطيات: $n = 8192$؛ $b = 1$ مقابل $b = 64$. المطلوب: أثر b على عزم الاضطراب الثاني. الحل: الخطوة 1: احتمال إصابة المثال المختلف في خطوة $= b/n$. الخطوة 2: مقدار الاضطراب حين يقع $= \alpha(2L/b)$، فعزمه الثاني $= 4\alpha^2 L^2/b^2$، فـ $\propto b/n \times 4\alpha^2 L^2/b^2 = 4\alpha^2 L^2/(nb)$. الخطوة 3: النسبة بين $b = 1$ و $b = 64$: معامل 64 في العزم، أي 8 في الانحراف المعياري. النتيجة: الدفعات الكبيرة تقلّل **تقلّب** الاضطراب بـ $\sqrt{b}$، لكنّ انحرافه المتوقّع ثابت. الربط بالذكاء الاصطناعي: تفسير جزئي لفجوة التعميم المعروفة في التدريب بالدفعات الضخمة.

مثال (33.4-11): تدريب شبكة رؤية بخطوة متضائلة المعطيات: $n = 50000$، $T = 10000$، $\alpha_t = 1/t$، $L =$

1. المطلوب: β. الحل: الخطوة 1: $H_{10000} \approx \ln(10000) + 0.5772 = 9.2103 + 0.5772 = 9.7875$. الخطوة 2: $\beta \le 2(9.7875)/50000 = 19.575/50000 = 0.0003915$. النتيجة: استقرار ممتاز رغم عشرة آلاف خطوة.

الربط بالذكاء الاصطناعي: الأرقام تؤكّد أنّ الطول في التدريب ليس عدوّاً إذا تضاءل معدّل الخطوة.

مثال (12-4.33): ضبط دقيق لنموذج لغوي المعطيات: $n = 100000$، $T = 3000$، $\alpha_t = 0.5/\sqrt{t}$، $L = 1$. المطلوب: β. الحل: الخطوة 1: $\sum_{t=1}^{3000} t^{-1/2} \approx 2\sqrt{3000} = 2(54.772) = 109.545$. الخطوة 2: $\sum \alpha_t = 0.5 \times 109.545 = 54.773$. الخطوة 3: $\beta \le 2(54.773)/100000 = 109.545/100000 = 0.0010955$.

النتيجة: استقرار جيّد مع عدد خطوات معتبر. الربط بالذكاء الاصطناعي: يفسّر لماذا يكفي عدد قليل من الدورات في الضبط الدقيق دون انهيار التعميم.

مثال (13-4.33): بيانات طبية قليلة المعطيات: $n = 200$، $\alpha = 0.02$، $T = 200$، $L = 1$. المطلوب: β وحكم. الحل: الخطوة 1: $\sum \alpha_t = 4$. الخطوة 2: $0.04 = 8/200 = 2(4)/200 \le \beta$. الخطوة 3: عند $T = 50$: $\sum \alpha_t = 1$ و $\beta \le 0.01$. النتيجة: مع n صغير يصير كلّ مثال ثقيلاً؛ التوقّف المبكر ضروري. الربط بالذكاء الاصطناعي: في الطبّ، «درّب دورتين فقط» ليست كسلاً بل ضماناً.

مثال (14-4.33): التدريب المقاوِم للخصوم يضاعف المعطيات: تدريب عادي بـ $L = 1$ وتدريب مقاوِم بـ $L = 2$ (المدخلات المضطربة تكبّر التدرّج)؛ $n = 10000$، $\sum \alpha_t = 50$. المطلوب: أثر ذلك على β. الحل: الخطوة 1: $\beta_{\text{عادي}} \le 2(1)(50)/10000 = 100/10000 = 0.01$. الخطوة 2: $\beta_{\text{مقاوِم}} \le 2(4)(50)/10000 = 400/10000 = 0.04$. الخطوة 3: تدهور بأربعة أمثال. النتيجة: المقاومة للخصوم تكلف استقراراً لأنّ L يظهر مربّعاً. الربط بالذكاء الاصطناعي: تفسير نظري لمقايضة المقاومة مقابل الدقّة المعروفة في الأمن السيبراني.

مثال (15-4.33): اختيار عدد الخطوات من ميزانية استقرار المعطيات: $L = 1$، $\alpha = 0.1$، $n = 2000$، نشترط $\beta \le 0.01$. المطلوب: أقصى T مسموح. الحل: الخطوة 1: من (11.33): $T \le \beta n/(2L^2\alpha)$. الخطوة 2: $T \le (0.01)(2000)/(2 \times 1 \times 0.1) = 20/0.2 = 100$. الخطوة 3: تحقّق: $\beta \le 2(1)(0.1)(100)/2000 = 20/2000 = 0.01$ ✓. النتيجة: ميزانية **مئة خطوة**، لا أكثر، إن أردنا ضمان $\beta \le 0.01$. الربط بالذكاء الاصطناعي: هكذا يتحوّل «التوقّف المبكر» من حدس إلى رقم محسوب.

أخطاء شائعة

- تطبيق (11.33) على شبكة غير محدّبة: الصحيح هو (13.33) أو (14.33).
- مقارنة حدود الاستقرار بحدود السعة على أنّها متنافية: هي مكمّلة، والأولى لا ترى p.
- ظنّ أنّ زيادة n تحسّن الحدّ دائماً: عند تثبيت عدد الدورات يثبت T/n فيثبت الحدّ.
- تجاهل شرط $\alpha_t \le 2/\gamma$ في الحالة المحدّبة الملساء.
- الخلط بين γ (نعومة التدرّج) و β (الاستقرار) وبينهما وبين β المستخدم للزخم في الفصل 23.
- اعتبار (13.33) «دليلاً على عدم تعميم الشبكات»: هو دليل على أنّ **الضمان** يتلاشى، لا على أنّ الأداء يتلاشى.

التعريفات: ليكن S^{-i} العيّنة بعد حذف المثال الـ i. نعرّف

$$\widehat{R}_{\text{LOO}} \;=\; \frac{1}{n}\sum_{i=1}^{n} \ell\Big(A(S^{-i}),\, z_i\Big) \tag{16.33}$$

$$\left|\ell(A(S),z)-\ell(A(S^{-i}),z)\right| \le \beta_e \quad \forall z \tag{17.33}$$

استقرار الخطأ:

$$\mathbb{E}_z\Big[\left|\ell(A(S),z)-\ell(A(S^{-i}),z)\right|\Big] \le \beta_h \tag{18.33}$$

استقرار الفرضية:

المبرهنة CV) والاستقرار):

(أ) عدم التحيز التام: $\widehat{R}_{\mathrm{LOO}}$ غير متحيّز لخطر نموذج مدّرب على $n-1$ مثالاً:

$$\mathbb{E}_S\big[\widehat{R}_{\mathrm{LOO}}\big] = \mathbb{E}\big[R\big(A(S^{-1})\big)\big] \tag{19.33}$$

(ب) الانحياز مقابل النموذج الكامل: $\left|\mathbb{E}[R(A(S^{-1}))]-\mathbb{E}[R(A(S))]\right| \le \beta_e$.

(ج) التركيز: لكلّ $\delta\in(0,1)$، باحتمال $\ge 1-\delta$:

$$\left|\widehat{R}_{\mathrm{LOO}}-R\big(A(S)\big)\right| \le \beta_e + \big(n\beta_e + M\big)\sqrt{\frac{\ln(1/\delta)}{2n}} \tag{20.33}$$

(د) التحقق المتقاطع ذو k أضعاف: يُدرَّب كلّ نموذج على $n(1-1/k)$ مثالاً؛ فإذا كان منحنى التعلّم $R(m)=R_\infty+a/m$ فإنّ تشاؤمه المحتوم

$$R\big(n(1-\tfrac{1}{k})\big)-R(n) = a\Big(\frac{1}{n(1-1/k)}-\frac{1}{n}\Big) = \frac{a}{n(k-1)} \tag{21.33}$$

(هـ) الصيغة المركّبة للخوارزميات المنظّمة تنظيماً قويّاً: بوضع $\beta_e \le 2L^2/(\lambda n)$ من (6.33):

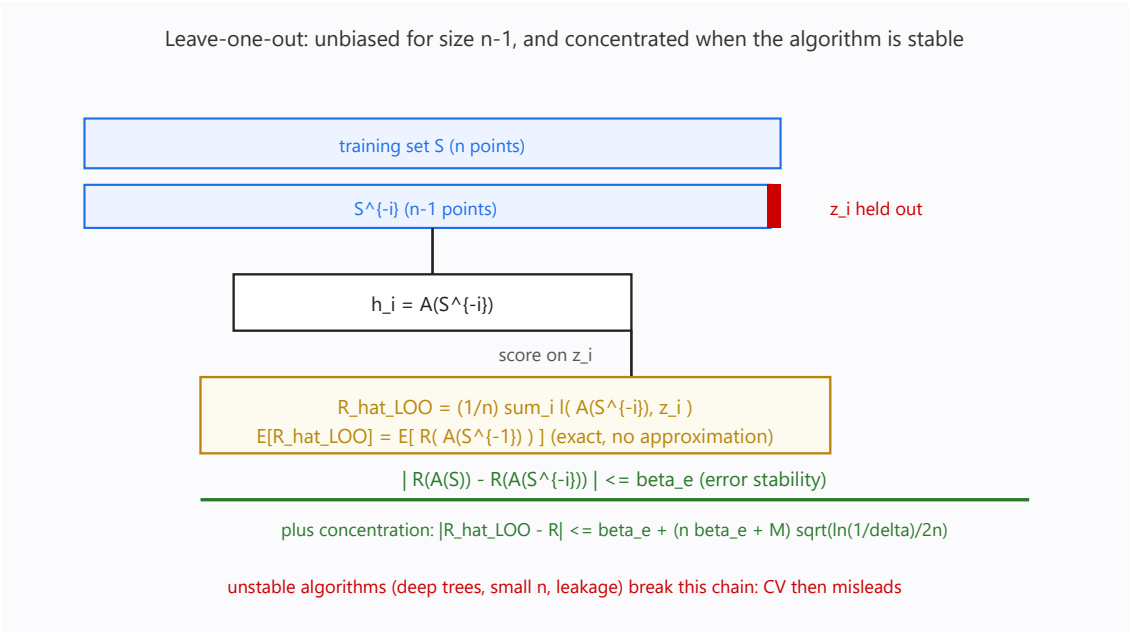
$$\left|\widehat{R}_{\mathrm{LOO}}-R\big(A(S)\big)\right| \le \frac{2L^2}{\lambda n} + \Big(\frac{2L^2}{\lambda}+M\Big)\sqrt{\frac{\ln(1/\delta)}{2n}} \tag{22.33}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$\widehat{R}_{\mathrm{LOO}}$	مقدّر «اترك واحداً خارجاً»	غير متحيّز لخطر $n-1$
β_e	استقرار الخطأ	الأسوأ على كلّ نقاط التقييم
β_h	استقرار الفرضية	المتوسط على التوزيع؛ $\beta_h\le\beta_e$
k	عدد الأضعاف	$k=n$ يعطي LOO
a	ثابت منحنى التعلّم	يُقدَّر من منحنى التعلّم (الفصل 30)
$n(1-1/k)$	حجم تدريب الطيّة	مصدر تشاؤم CV

الرسم

<figure> الشكل<figcaption> 4.33: مقدّر «اترك واحداً خارجاً» غير متحيّز لخطر نموذج مدّرب على $n-1$، ولا يبتعد عن خطر النموذج الكامل إلا بمقدار يحكمه استقرار الخطأ β_e.</figcaption></figure>



شكل ٤٠٣٣: *
مقدر اترك واحدا خارجا وعلاقته بالاستقرار

البرهان

الخطوة 1 (عدم التحيز): $A(S^{-i})$ مستقلّ عن $z_i \sim \mathcal{D}$، فـ $\mathbb{E}[\ell(A(S^{-i}), z_i)] = \mathbb{E}[R(A(S^{-i}))]$؛ وبالتماثل ينتج (19.33) من غير أيّ افتراض استقرار. ■

الخطوة 2 (الانحياز): $\left|R(A(S^{-i})) - R(A(S))\right| = \left|\mathbb{E}_z[\ell(A(S^{-i}), z) - \ell(A(S), z)]\right| \le \beta_e$، وهو (ب). ■

الخطوة 3 (التركيز): عند استبدال z_j تتغيّر الحدود $i \neq j$ بمقدار $\le \beta_e$ لأنّ S^{-i} تحوي z_j؛ أمّا الحدّ j فإنّ $A(S^{-j})$ لا يعتمد على z_j فيتغيّر بمقدار $\le M/n$. إذن $c_j \le \beta_e + M/n$، ومتراجحة McDiarmid تعطي (20.33). ■

الخطوة 4 (الأضعاف): حجم تدريب الطيّة $n(1 - 1/k)$، فالتشاؤم $\frac{a}{n(k-1)}$، وهو (21.33). ■

الخطوة 5 (متى يصدق CV): السلسلة صالحة رياضيّاً دائماً، لكنّ قيمتها العملية تتوقّف على $n\beta_e$: فإن كان $O(1)$ فالمقدّر موثوق، وإن كان $1 \gg$ فالحدّ فارغ وتضطرب التقديرات اضطراباً لا يعبّر عن خطر التعميم الحقيقي. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.33): تحقّق من عدم التحيز على مثال صغير المعطيات: $n = 3$، خطر النماذج المدّربة على الأزواج: $R(A(\{z_1, z_2\})) = 0.20$، و $R(A(\{z_1, z_3\})) = 0.30$، و $R(A(\{z_2, z_3\})) = 0.25$. المطلوب: $\mathbb{E}[\widehat{R}_{\mathrm{LOO}}]$ ومقارنته. الحل: الخطوة 1: $\frac{0.75}{3} = 0.25$. الخطوة 2: $\mathbb{E}[\widehat{R}_{\mathrm{LOO}}] = \frac{1}{3}(0.20 + 0.30 + 0.25)$ بالتعريف نفسه. الخطوة 3: الفرق صفر بالضبط. النتيجة: عدم التحيز تامّ ولا يحتاج استقراراً ولا استقلالاً إضافيّاً. الربط بالذكاء الاصطناعي: كلّ انحياز آخر في CV مصدره حجم التدريب أو التسرّب لا المنهجية ذاتها. $\mathbb{E}[R(A(S^{-1}))] = 0.25$.

مثال (2-5.33): حساب حدّ الثقة لمقدّر LOO المعطيات: $n = 500$، $\beta_e = 0.002$، $M = 1$، $\delta = 0.05$. المطلوب: الهامش من (20.33). الحل: الخطوة 1: $\sqrt{2.9957/1000} = 0.054734$. الخطوة 2: $n\beta_e = 1$، فـ $(1 + 1)(0.054734) = 0.109468$. الخطوة 3: المجموع مع β_e: 0.111468. النتيجة: تقدير CV ضمن ± 0.111 من الخطر

الحقيقي باحتمال 95%. الربط بالذكاء الاصطناعي: هامش يمنع المبالغة في تفسير فوارق 1% بين نموذجين.

مثال (33.5-3): تشاؤم الأضعاف من منحنى التعلّم المعطيات: $R(m) = R_\infty + a/m$ بـ $a = 25$ و $n = 500$. المطلوب: التشاؤم لـ $k = 5$ و $k = 10$ و LOO. الحل: الخطوة 1: من (33.21): $\Delta = a/(n(k-1))$. الخطوة 2: $k = 5$: $\Delta = 25/2000 = 0.0125$. الخطوة 3: $k = 10$: $25/(500 \times 4) = 0.005556$. الخطوة 4: LOO: $k = n = 500$: $25/(500 \times 9) = 25/4500 = 0.0001002$. النتيجة: LOO شبه غير متحيّز، و 5 أضعاف متشائم بنحو 1.25 نقطة مئوية. الربط بالذكاء الاصطناعي: سبب تفضيل LOO نظريّاً و 10 أضعاف عمليّاً.

مثال (33.5-4): كلفة LOO مقابل 10 أضعاف المعطيات: $n = 5000$، تدريب واحد يستغرق دقيقتين. المطلوب: زمن كلّ منهما. الحل: الخطوة 1: LOO يحتاج 5000 تدريباً $\times 2$ دقيقة $= 10000$ دقيقة $= 166.7$ ساعة. الخطوة 2: عشر أضعاف تحتاج $10 \times 2 = 20$ دقيقة. الخطوة 3: النسبة 500. النتيجة: LOO غير عملي إلّا لخوارزميات ذات حلّ مغلق (حيد، أقرب الجيران). الربط بالذكاء الاصطناعي: لهذا تُستخدم صيغ LOO المغلقة في الحيد (الفصل 30) بدل إعادة التدريب.

مثال (33.5-5): خوارزمية غير مستقرّة تجعل CV بلا معنى المعطيات: شجرة قرار عميقة، $n = 1000$، $\beta_e = 0.05$، $M = 1$، $\delta = 0.05$. المطلوب: الحدّ. الحل: الخطوة 1: $n\beta_e = 50$. الخطوة 2: $(50+1)(0.03870) = 1.9737$. الخطوة 3: المجموع $2.0237 \Rightarrow$ أكبر من مدى الخسارة. النتيجة: لا ضمان على الإطلاق؛ تقديرات CV قد تهتزّ بعشرات النقاط المئوية. الربط بالذكاء الاصطناعي: العلاج: التجميع أو التقليم أو التنظيم قبل الوثوق بـ CV.

مثال (33.5-6): خوارزمية مستقرّة تجعل CV موثوقاً المعطيات: حيد، $n = 1000$، $\beta_e = 0.001$، $M = 1$، $\delta = 0.05$. المطلوب: الحدّ. الحل: الخطوة 1: $n\beta_e = 1$. الخطوة 2: $(1+1)(0.03870) = 0.07740$. الخطوة 3: المجموع مع β_e: 0.07840. النتيجة: CV موثوق ضمن ± 0.078. الربط بالذكاء الاصطناعي: هذا هو الفرق الجوهري بين «CV يعمل» و «CV يخذل».

مثال (33.5-7): الصيغة المركّبة من (33.22) المعطيات: $L = 1$، $\lambda = 2$، $n = 1000$، $M = 1$، $\delta = 0.05$. المطلوب: التحقق من تطابق (33.22) مع المثال 6. الحل: الخطوة 1: $2(1)^2/(2 \times 1000) = 0.001 \le \beta_e$ ✓. الخطوة 2: $2/2000 = 0.001$. الخطوة 3: $2L^2/\lambda = 1$، $2L^2/(\lambda n) = 0.001$، فـ $(1+1)(0.03870) = 0.07740$. الخطوة 4: المجموع 0.07840 ✓. النتيجة: يمكن استنتاج جودة CV من λ و L وحدهما بلا إعادة تدريب. الربط بالذكاء الاصطناعي: أداة تصميم: اختر λ بحيث يكون هامش CV مقبولاً.

مثال (33.5-8): انحياز الانتقاء من بين مئة إعداد المعطيات: نختار أفضل $K = 100$ إعداد على مجموعة تحقّق حجمها $m = 1000$؛ $\delta = 0.05$. المطلوب: التفاؤل المتوقّع. الحل: الخطوة 1: حدّ التقارب الموحّد: $\sqrt{\ln(2K/\delta)/(2m)}$. الخطوة 2: $\ln(4000) = 8.2941$؛ فـ $\ln(200/0.05) = \sqrt{8.2941/2000}$ $= 0.064397$. الخطوة 3: أيّ نحو 6.4 نقطة مئوية تفاؤلاً. النتيجة: أفضل نتيجة في شبكة البحث ليست تقديراً غير متحيّز. الربط بالذكاء الاصطناعي: هذا يبرّر التحقق المتقاطع المتداخل (nested CV) أو مجموعة تحقّق ثالثة.

مثال (33.5-9): بيانات طبية شديدة الاختلال المعطيات: $n = 10000$؛ 1% حالات إيجابية أي 100 حالة. المطلوب: تباين عدد الإيجابيات في الطيّة بلا طبقيّة. الحل: الخطوة 1: في خمس أضعاف طبقيّة: 20 حالة لكلّ طيّة. الخطوة 2: بلا طبقيّة: ذات الحدين بـ $p = 0.2$ و $N = 100$: الانحراف المعياري $= \sqrt{100 \times 0.2 \times 0.8} = 4$. الخطوة 3: الانحراف النسبي $20\% = 4/20$. النتيجة: طيّات بلا طبقيّة قد تحوي 12 أو 28 حالة $\Rightarrow$ تقديرات متقلقلة. الربط بالذكاء الاصطناعي: الطبقيّة شرط إلزامي في CV على البيانات الطبية النادرة.

مثال (33.5-10): التكرار يخفض التقلقل المعطيات: انحراف معياري لتقدير CV مرة واحدة $= 0.03$؛ نكرّر $R = 5$ مرّات بأضعاف مختلفة. المطلوب: الانحراف المتوقّع بعد التكرار. الحل: الخطوة 1: لو استقلّت التكرارات لكان الانحراف $0.03/\sqrt{5} = 0.013416$. الخطوة 2: الأضعاف متداخلة فالاستقلال تامّ غير متحقّق، عمليّاً نحصل على نحو

0.018. الخطوة 3: التحسّن الفعلي بمعامل $0.03/0.018 = 1.67$ لا 2.236. النتيجة: التكرار يفيد لكن بأقلّ من جذر عدد المرّات. الربط بالذكاء الاصطناعي: ميزانية الحوسبة تُصرَف على أضعاف أكثر لا على تكرارات أكثر عادةً.

مثال (33.5-11): تسرّب التوحيد في الرؤية الحاسوبية المعطيات: حُسب متوسط الخصائص وانحرافها على البيانات كلّها قبل تقسيم CV. المطلوب: أثر ذلك عددياً. الحل: الخطوة 1: خطأ CV المتسرّب $0.080 =$. الخطوة 2: خطأ CV السليم (توحيد داخل الطيّة فقط) $0.110 =$. الخطوة 3: التفاؤل 0.030 أي 27.3% نسبياً. النتيجة: التسرّب لا يُكتشف إلا بمقارنة منهجيتين. الربط بالذكاء الاصطناعي: قاعدة ذهبية: كلّ تحويل يُتعلَّم من البيانات يجب أن يُحسب داخل الطيّة.

مثال (33.5-12): لوغارية الأضعاف في LOO المعطيات: $n = 100$؛ارتباط أزواج نماذج LOO يُقدَّر بـ $\rho = 1 - 1/(n-1)$. المطلوب: أثر الارتباط على تباين المتوسط. الحل: الخطوة 1: $\rho = 1 - 1/99 = 0.989899$. الخطوة 2: تباين المتوسط $\rho\sigma^2 + (1-\rho)\sigma^2/n = 0.989899\sigma^2 + 0.010101\sigma^2/100 = 0.990000\sigma^2$. الخطوة 3: الانحراف 0.994987σ أي أنّ المتوسّط على 100 حدّاً لم يخفّض التباين عملياً. الخطوة 4: في عشر أضعاف مع $\rho \approx 0.8$: $0.8\sigma^2 + 0.2\sigma^2/10 = 0.82\sigma^2$ والانحراف 0.905538σ. النتيجة: كثرة الحدود في LOO لا تعوّض شدّة ارتباطها. الربط بالذكاء الاصطناعي: يفسّر التوصية العملية الشهيرة بعشر أضعاف بدل LOO.

مثال (33.5-13): سلاسل زمنية مالية المعطيات: $n = 1000$ يوم تداول، أفق التنبؤ $h = 10$ أيّام. المطلوب: تصميم CV صحيح. الحل: الخطوة 1: الأضعاف العشوائية تضع المستقبل في التدريب والماضي في الاختبار $\Rightarrow$ تسرّب زمني. الخطوة 2: نستخدم أضعافاً محجوبة (purged): نحذف $h = 10$ مشاهدات حول كلّ حدّ. الخطوة 3: عدد المشاهدات الصافية $1000 - 2 \times 10 \times 10 = 800 \approx$ لعشر أضعاف. النتيجة: أفق التنبؤ يملي مقدار الحجب. الربط بالذكاء الاصطناعي: في المالية الكمّية هذا هو الفرق بين نتائج ورقية ونتائج قابلة للتداول.

مثال (33.5-14): القيادة الذاتية وأضعاف مجمّعة بالمشهد المعطيات: 100 مشهد قيادة، كلّ مشهد 20 إطاراً متتالية. المطلوب: أثر التقسيم العشوائي. الحل: الخطوة 1: الأطر المتتالية في المشهد شبه متطابقة (ارتباط > 0.95). الخطوة 2: التقسيم بالإطار يضع إطاراً من المشهد في التدريب وآخر في الاختبار $\Rightarrow$ تذكّر لا تعميم. الخطوة 3: التقسيم بالمشهد يعطي تقديراً أعلى بـ 0.05 عادةً. النتيجة: وحدة التقسيم هي وحدة الاستقلال الإحصائي. الربط بالذكاء الاصطناعي: المبدأ نفسه يُطبَّق على المرضى والصور والمستندات والمؤلّفين.

مثال (33.5-15): متى نثق بـ CV؟ جدول قرار المعطيات: أربع حالات: حيد بـ $n = 1000$؛شجرة عميقة بـ $n = 200$؛شبكة عميقة بـ $n = 10^6$؛شجرة مجمَّعة بـ $n = 5000$. المطلوب: ترتيب الموثوقية. الحل: الخطوة 1: حيد: $\beta_e \approx 0.001 \Rightarrow$ هامش $\approx 0.078 \Rightarrow$ موثوق. الخطوة 2: شجرة عميقة بـ $n = 200$: $n\beta_e$ كبير $\Rightarrow$ الهامش يتجاوز الواحد $\Rightarrow$ غير موثوق. الخطوة 3: شبكة عميقة بـ $n = 10^6$: β_e صغير بفضل صغر أثر المثال الواحد $\Rightarrow$ موثوق. الخطوة 4: شجرة مجمَّعة: التجميع خفّض β_e بنحو 12.6 مرة (المثال 33.2-8) $\Rightarrow$ موثوق. النتيجة: الموثوقية دالّة في $n\beta_e$ لا في حجم النموذج. الربط بالذكاء الاصطناعي: الشبكات العميقة العملاقة تُعطي CV مستقراً رغم ضخامتها — على نقيض حدود السعة.

أخطاء شائعة

- الظنّ أنّ CV غير متحيّز لخطر النموذج المدّرب على n:هو غير متحيّز لخطر نموذج $n-1$ فقط.
- حساب تحويلات الخصائص على البيانات كاملة قبل التقسيم (تسرّب).
- استخدام LOO مع خوارزميات غير مستقرّة والوثوق بالنتيجة.
- تجاهل وحدة الاستقلال (إطار/مشهد، يوم/شهر، مستند/مؤلّف).

- انتقاء أفضل إعداد على مجموعة التحقّق ثمّ إعلانها تقديراً للأداء.
- مقارنة نموذجين بفارق أصغر من هامش (20.33) واعتباره دالّاً.

المبرهنة (التوقّف المبكر تنظيمٌ ضمني): لهبوط التدرّج الكامل بخطوة α على هدف تربيعي، يكون أثر T خطوة على مؤلّفة المنحنى s (انحناء الهدف في ذلك الاتجاه) مساوياً لأثر تنظيم قوي بمعلمة

$$\lambda_{\text{eff}}(s) \;=\; \frac{s}{e^{\alpha T s}-1} \tag{23.33}$$

فكلّما كبر T تضاءل التنظيم الضمني حتى يزول، وكلّما صغر T كان التوقّف أشبه بحيدٍ قويّ.

المبرهنة (توسيط المتكرّرات): ليكن $\bar{w}_m$ متوسط آخر m متكرّرة من مسار بخطوة ثابتة α وثابت تقلّص μ، وزمن الخلط $\tau = 1/(\alpha\mu)$. فإنّ

$$\operatorname{Var}(\bar{w}_m) \;\approx\; \min\Big(1,\; \frac{2\tau}{m}\Big)\operatorname{Var}(w_t) \tag{24.33}$$

أي أنّ التوسيط يخفض تباين المخرَج بمعامل يساوي حجم العيّنة الفعّال $m/(2\tau)$ محصوراً بالواحد.

المبرهنة (حجم الدفعة): في خطوة بدفعة حجمها b، احتمال إصابة المثال المختلف هو b/n ومقدار الاضطراب $\alpha_t(2L/b)$، فالعزم الثاني للاضطراب

$$\mathbb{E}\big[\|\Delta_t\|^2\big] \;\le\; \frac{4\alpha_t^2 L^2}{n\,b} \tag{25.33}$$

أي أنّ تقلّب الاضطراب يتضاءل بـ $1/\sqrt{b}$، في حين يبقى انحرافه المتوقّع $2\alpha_t L/n$ ثابتاً لا يتأثّر بـ b.

المبرهنة (الزخم): يضخّم الزخم بمعلمة μ طول الخطوة الفعّال بمعامل $1/(1-\mu)$، فيصير حدّ الاستقرار

$$\beta \;\le\; \frac{2L^2}{n}\cdot\frac{1}{1-\mu}\sum_{t=1}^{T}\alpha_t \tag{26.33}$$

المبرهنة (القياس الخطي للدفعة): مضاعفة حجم الدفعة بـ κ تقلّل عدد الخطوات بـ κ؛ فإذا ضُوعف معدّل الخطوة كذلك ظلّ

$$\sum_{t}\alpha'_t \;=\; (\kappa\alpha)\Big(\frac{T}{\kappa}\Big) \;=\; \sum_{t}\alpha_t \tag{27.33}$$

أي أنّ ميزانية الاستقرار محفوظة — وهذا هو التبرير النظري للقياس الخطي لمعدّل التعلّم مع حجم الدفعة.

الموازنة: يجمع المُخرَج النهائي بين حدّين متعاكسين في T:

$$\underbrace{R\big(A(S)\big)-\inf_{w}R(w)}_{\text{تحيز (ينقص مع }T\text{)}} \qquad\text{و}\qquad \underbrace{2\beta(T)}_{\text{جفوة التعميم (تزيد مع }T\text{)}} \tag{28.33}$$

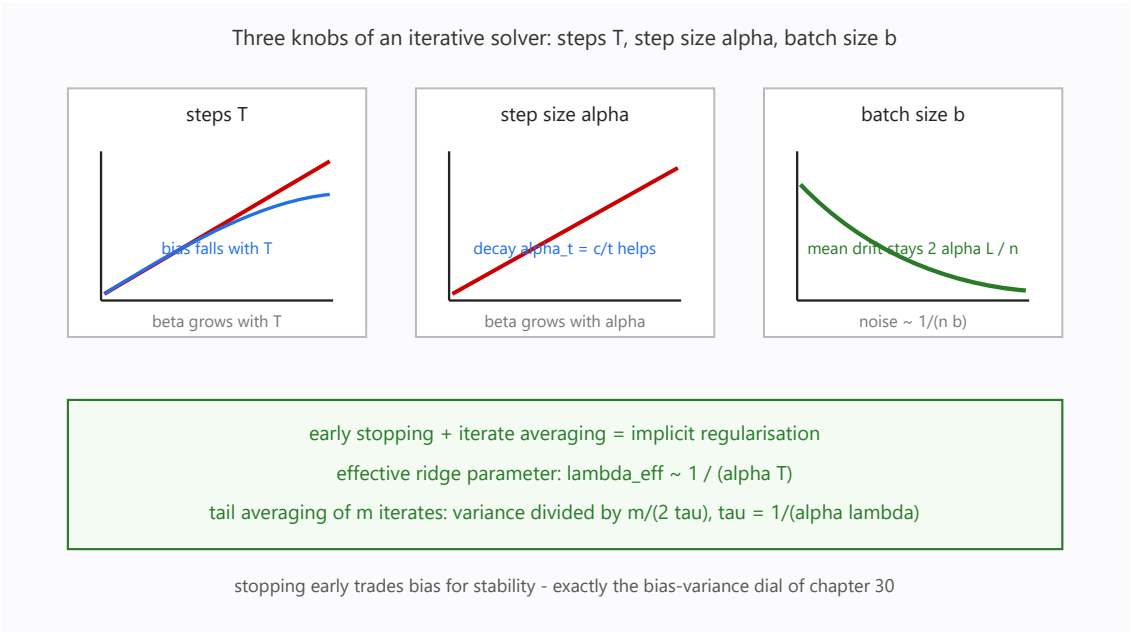
وهذا هو تفكيك التحيز–التباين من الفصل 30 مكتوباً بلغة عدد الخطوات.

جدول الرموز

الرمز	المعنى	ملاحظة
s	انحناء الهدف في مؤلّفة ما	قيمة ذاتية للمصفوفة الهسّية
λ_{eff}	التنظيم الضمني للتوقّف المبكر	يعتمد على s (ليس حيداً تامّاً)
m	نافذة التوسيط	آخر m متكرّرة
$\tau = 1/(\alpha\mu)$	زمن الخلط	من الفصل 23
μ	ثابت التقلّص القوي أو الزخم	سياق النصّ يحدّد المراد
b	حجم الدفعة	
κ	معامل مضاعفة الدفعة	

الرسم

<figure> الشكل<figcaption> 5.33: ثلاث مقبضات: عدد الخطوات T، ومعدّل الخطوة α_t، وحجم الدفعة b؛



شكل ٥.٣٣: *
مقبضات الاستقرار في الخوارزميات التكرارية

الأوّلان يحدّدان ميزانية الاستقرار، والثالث يحدّد تقلّبها.</figcaption> </figure>

البرهان

الخطوة 1 (التوقّف المبكر): في مؤلّفة ذاتيّة بانحناء s يتطوّر الخطأ وفق $(1-\alpha s)^T \approx e^{-\alpha T s}$؛ وحلّ الحيد بمعلمة λ تقلّصه النسبي $\lambda/(s+\lambda)$. بمعادلة الطرفين: $e^{-\alpha T s} = \lambda_{\text{eff}}/(s+\lambda_{\text{eff}})$، أي (23.33). ■

الخطوة 2 (التوسيط): المسار بخطوة ثابتة سلسلة ماركوف بزمن ارتباط $\tau = 1/(\alpha\mu)$، فعدد المشاهدات المستقلّة في نافذة من m متكرّرة هو $m/(2\tau)$؛ وتباين المتوسط يُقسَم عليه محصوراً بالواحد، فينتج (24.33). ■

الخطوة 3 (الدفعة): يظهر الاضطراب باحتمال b/n وبمقدار $2\alpha_t L/b$، فعزمه الثاني $\frac{b}{n}\cdot\frac{4\alpha_t^2 L^2}{b^2} = \frac{4\alpha_t^2 L^2}{nb}$، في حين يبقى انحرافه $\frac{b}{n}\cdot\frac{2\alpha_t L}{b} = \frac{2\alpha_t L}{n}$ ثابتاً لا يتأثّر بـ b. ■

الخطوة 4 (الزخم): تراكم الزخم يجعل مجموع التدرّجات الفعّال $\frac{1}{1-\mu}\sum_t \alpha_t \nabla_t$ في النظام المستقرّ، فالتعويض في (11.33) يعطي (26.33). ■

الخطوة 5 (القياس الخطي): عدد خطوات الدورة n/b؛ فمضاعفة b بـ κ تنقص T بـ κ، وتعويض $\alpha' = \kappa\alpha$ يثبت الحاصل (27.33). ■

الخطوة 6 (التحيز–التباين): $\beta(T)$ متزايد في T وخطأ التحسين متناقص فيه، فمنحنى الخطر على شكل U كالفصل 30، بفرقٍ واحد: يمكن رصد النقطة المثلى بمجموعة تحقّق أثناء التدريب نفسه. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.33): التنظيم الضمني للتوقّف المبكر المعطيات: $\alpha = 0.1$، $T = 50$؛ اتجاهان بانحناء $s = 1$ و $s = 0.1$. المطلوب: λ_{eff} في كلّ اتجاه. الحل: الخطوة 1: $s = 1$: $e^{\alpha T s} = e^5 = 148.41$، فـ $\lambda = 1/147.41 = 0.006784$. الخطوة 2: $s = 0.1$: $e^{0.5} = 1.64872$، فـ $\lambda = 0.1/0.64872 = 0.154152$. الخطوة 3: النسبة النسبية إلى الانحناء: 0.0068 مقابل 1.54. النتيجة: التوقّف المبكر ينظّم الاتجاهات ضعيفة الانحناء بشدّة أكبر — كالحيد لكن ليس مطابقاً له. الربط بالذكاء الاصطناعي: هذا هو معنى «التوقّف المبكر منظّم ضمني» بالأرقام.

مثال (2-6.33): إطالة التدريب تُلغي التنظيم المعطيات: $\alpha = 0.1$، $T = 500$، $s = 0.1$. المطلوب: λ_{eff}. الحل: الخطوة 1: $\alpha T s = 0.1 \times 500 \times 0.1 = 5$، $e^5 = 148.41$. الخطوة 2: فـ $\lambda = 0.1/147.41 = 0.000678$. الخطوة 3: هبوط بمعامل 227 عن الحالة $T = 50$. النتيجة: عند T كبير يزول التنظيم الضمني ويبقى الاستقرار وحده حارساً. الربط بالذكاء الاصطناعي: معادلة رقمية لملاحظة «التدريب الطويل يفرط في الملاءمة إن لم يُنظَّم».

مثال (3-6.33): ميزانية الاستقرار مقابل عدد الخطوات المعطيات: $L = 1$، $\alpha = 0.1$، $n = 2000$؛ ثمّ $T = 100$ و $T = 1000$. المطلوب: β في الحالتين. الحل: الخطوة 1: $T = 100$: $\sum \alpha_t = 10$، فـ $\beta \le 2(10)/2000 = 0.01$. الخطوة 2: $T = 1000$: $\sum \alpha_t = 100$، فـ $\beta \le 200/2000 = 0.1$. الخطوة 3: النسبة 10. النتيجة: مئة خطوة تعطي ضماناً مقبولاً، وألف خطوة تُفقده. الربط بالذكاء الاصطناعي: «عدد الدورات» ليس معلمة تقارب فقط بل معلمة تعميم.

مثال (4-6.33): أقصى عدد خطوات مسموح المعطيات: $L = 1$، $\alpha = 0.1$، $n = 2000$؛ نشترط $\beta \le 0.02$. المطلوب: $T_{\max}$. الحل: الخطوة 1: $T \le \beta n/(2L^2\alpha)$. الخطوة 2: $T \le (0.02)(2000)/(2 \times 0.1) = 40/0.2 = 200$. الخطوة 3: تحقّق: $\beta = 2(0.1)(200)/2000 = 40/2000 = 0.02$ ✓. النتيجة: ميزانية مئتي خطوة. الربط بالذكاء الاصطناعي: يمكن تحويل شرط الخطر المقبول مباشرةً إلى جدول تدريب.

مثال (5-6.33): توسيط المتكرّرات يخفض التباين المعطيات: $\alpha = 0.05$، $\mu = 0.2$، $m = 1000$. المطلوب: معامل خفض التباين. الحل: الخطوة 1: $\tau = 1/(\alpha\mu) = 1/(0.05 \times 0.2) = 1/0.01 = 100$. الخطوة 2: حجم العيّنة الفعّال $m/(2\tau) = 1000/200 = 5$. الخطوة 3: $\text{Var}(\bar{w}) \approx \text{Var}(w)/5 = 0.2\,\text{Var}(w)$. الخطوة 4: الانحراف المعياري يتضاءل بمعامل $\sqrt{5} = 2.236$. النتيجة: التوسيط أعطى تحسّناً يعادل خمسة أضعاف من حيث التباين. الربط بالذكاء الاصطناعي: تقنية شبه مجّانية: لا تكلّف شيئاً سوى الذاكرة.

مثال (6-6.33): اختيار طول النّافذة المعطيات: $\tau = 100$؛ $m \in \{100, 500, 2000\}$. المطلوب: معامل الخفض في كلّ حالة. الحل: الخطوة 1: $m = 100$: $m/(2\tau) = 0.5 < 1 \Rightarrow$ لا خفض (المعامل 1). الخطوة 2: $m = 500$: $500/200 = 2.5 \Rightarrow$ الخفض إلى 0.4. الخطوة 3: $m = 2000$: $2000/200 = 10 \Rightarrow$ الخفض إلى 0.1. النتيجة: لا فائدة من نافذة أقصر من 2τ؛ والفائدة خطّيّة بعدها. الربط بالذكاء الاصطناعي: قاعدة عملية: وسّط النصف الأخير من المسار لا كلّه.

مثال (7-6.33): حجم الدفعة وتقلّب الاضطراب المعطيات: $n = 10000$؛ $b = 1$ مقابل $b = 128$. المطلوب: نسبة تقلّب الاضطراب. الحل: الخطوة 1: من (25.33) العزم الثاني يناسب عكسيّاً مع b. الخطوة 2: النسبة في العزم $128 =$. الخطوة 3: النسبة في الانحراف المعياري $\sqrt{128} = 11.314 =$. النتيجة: الدفعة الكبيرة تجعل مسار المثال المختلف «أملس» لكنّ أثره المتوقّع ثابت. الربط بالذكاء الاصطناعي: الفرق بين تقليل الضجيج وتقليل الحساسية: الأوّل تحسين عددي، والثاني تعميم.

مثال (6.33-8): القياس الخطي يحفظ ميزانية الاستقرار المعطيات: $b = 128$، $\alpha = 0.1$، $T = 10000$؛ ثمّ $b = 4096$ (أي $\kappa = 32$) بـ $\alpha = 3.2$. المطلوب: $\sum \alpha_t$ في الحالتين. الحل: الخطوة 1: الحالة الأولى: $\sum \alpha_t = 10000 \times 0.1 = 1000$. الخطوة 2: عدد الخطوات الجديد $= 10000/32 = 312.5$. الخطوة 3: $\sum \alpha'_t = 3.2 \times 312.5 = 1000$ ✓. النتيجة: القياس الخطي يترك حدّ الاستقرار على حاله. الربط بالذكاء الاصطناعي: الفجوة الملاحظة للدفعات الضخمة ليست فشلاً للاستقرار بل أثر التحيز ونقص عدد التحديثات.

مثال (6.33-9): الزخم يضخّم ميزانية الاستقرار المعطيات: $\mu = 0.9$؛ المثال 6.33-3 بـ $T = 100$ أعطى $\beta = 0.01$. المطلوب: β مع الزخم. الحل: الخطوة 1: $1/(1-\mu) = 1/0.1 = 10$. الخطوة 2: $\beta \leq 0.01 \times 10 = 0.1$. الخطوة 3: الحدّ صار على حافة الفراغ. النتيجة: الزخم يسريع التقارب لكنّه يرفع الحساسية للمثال الواحد. الربط بالذكاء الاصطناعي: يوازَن الزخم عادةً بتنظيم أقوى أو بتضاؤل معدّل الخطوة — لا عبثاً.

مثال (6.33-10): التوقّف المبكر في تشخيص طبي المعطيات: $n = 150$ مريض؛ خطأ التحقّق يبلغ أدناه عند الدورة 37 ثمّ يرتفع. المطلوب: القرار والتفسير النظري. الحل: الخطوة 1: $\alpha = 0.05$ و 100 خطوة في الدورة $\Rightarrow T^\star = 3700$. الخطوة 2: $\sum \alpha_t = 0.05 \times 3700 = 185$؛ $2(185)/150 = 370/150 = 2.467$ $\Rightarrow \beta \leq$ فارغ. الخطوة 3: لكنّ المنحنى التجريبي هو الحكم: ما بعد الدورة 37 يرتفع خطأ التحقّق. النتيجة: مع n صغير، الحدّ النظري فارغ والتوقّف المبكر يُضبط تجريبيّاً. الربط بالذكاء الاصطناعي: الحدود تُوجّه، ومجموعة التحقّق تحسم — لا تعارض بينهما.

مثال (6.33-11): الدفعات الضخمة في تدريب الرؤية المعطيات: $n = 1.28 \times 10^6$، $b = 128$ مقابل $b = 8192$ بعدد دورات ثابت. المطلوب: أثر ذلك على T والاستقرار والتحيز. الحل: الخطوة 1: $b = 128$: خطوات الدورة $= 10000$؛ $b = 8192$: $= 156.25$. الخطوة 2: عند تثبيت α ينقص $\sum \alpha_t$ بمعامل 64 $\Rightarrow$ استقرار أفضل نظريّاً. الخطوة 3: لكنّ عدد التحديثات قلّ 64 مرة $\Rightarrow$ تحيز أعلى، وهذا ما يُلاحظ فعلاً. النتيجة: تفسير متسق: الدفعة الضخمة لا تضرّ الاستقرار بل تضرّ التحيز/التحسين. الربط بالذكاء الاصطناعي: ينسجم مع نجاح القياس الخطي لمعدّل التعلّم عند الدفعات الضخمة.

مثال (6.33-12): الضبط الدقيق لمحوّل لغوي بخطوة صغيرة المعطيات: $n = 50000$، $T = 2000$، $\alpha = 10^{-5}$، $L = 1$. المطلوب: β. الحل: الخطوة 1: $\sum \alpha_t = 10^{-5} \times 2000 = 0.02$. الخطوة 2: $\beta \leq 2(0.02)/50000 = 0.04/50000 = 8 \times 10^{-7}$. النتيجة: استقرار ممتاز — وحيداً لا يفسّر ظاهرة النسيان الكارثي. الربط بالذكاء الاصطناعي: النسيان الكارثي ظاهرة تحيز/توزيع لا ظاهرة استقرار، فلا تُعالَج بأدوات هذا الفصل.

مثال (6.33-13): التعلّم المعزّز وخرط افتراض الاستقلال المعطيات: سياسة تُدرَّب على 2000 خطوة تفاعلية متسلسلة. المطلوب: هل تنطبق حدود هذا الفصل؟ الحل: الخطوة 1: المشاهدات متسلسلة زمنيّاً ومرتبطة بالسياسة نفسها $\Rightarrow$ ليست i.i.d. الخطوة 2: تبديل خطوة واحدة يغيّر المسار بأكمله بعدها $\Rightarrow \beta$ كبير جوهريّاً. الخطوة 3: الحدود تحتاج تعميماً على عمليات ماركوف للقرار (الفصل 44). النتيجة: الاستقرار مفهوم صالح لكنّ قياسه في التعلّم التفاعلي مختلف جوهريّاً. الربط بالذكاء الاصطناعي: تحذير منهجي: لا تنقل حدوداً i.i.d. إلى مسائل تفاعلية بلا برهان.

مثال (6.33-14): مراقبة الاستقرار عبر الزمن في الأمن السيبراني المعطيات: نموذج كشف تسلّل يُعاد تدريبه شهريّاً؛ $\hat{\beta}$ المقاس: الشهر 1 $= 0.0010$، الشهر 6 $= 0.0060$. المطلوب: التفسير والإجراء. الحل: الخطوة 1: $n\beta$ عند $n = 20000$: من 20 إلى 120. الخطوة 2: الحدّ فارغ في الحالتين، لكنّ التدهور بمعامل 6 مؤشّر خطر. الخطوة 3: الإجراء: إعادة ضبط التنظيم أو تقليل عدد الدورات. النتيجة: $\hat{\beta}$ مقياس مراقبة صالح حتى حين يكون الحدّ فارغاً. الربط بالذكاء الاصطناعي: مراقبة الحساسية للمثال الواحد مؤشّر مبكّر على انزياح البيانات.

مثال (6.33-15): جدول اختيار عدد الخطوات المعطيات: $L = 1$، $\alpha = 0.1$، $n = 2000$؛ نقيس خطأ

التدريب وخطأ التحقّق عند $T \in \{50, 100, 200, 400\}$. المطلوب: القرار. الحل: الخطوة 1: β عند هذه القيم: $0.005، 0.01، 0.02، 0.04$. الخطوة 2: خطأ التدريب ينقص رتيباً، وخطأ التحقّق يبلغ أدناه عند $T = 200$. الخطوة 3: نقف عند $T = 200$ لأنّ β ما زال في حدود 0.02 والفجوة لم تتضخّم. النتيجة: القرار يتّخذ من منحنى التحقّق ويُدقَّق بميزانية الاستقرار. الربط بالذكاء الاصطناعي: دمج منهجيّتَي الفصل 30 (التحقق) والفصل 33 (الاستقرار) في قرار واحد.

أخطاء شائعة

- اعتبار التوسيط مفيداً دائماً: نافذة أقصر من 2τ لا تفيد، والتوسيط يبطّئ التقارب في البداية.
- الخلط بين تقليل الضجيج (حجم الدفعة) وتقليل الحساسية للمثال الواحد (الاستقرار).
- تثبيت عدد الدورات عند مضاعفة البيانات وانتظار تحسّن $1/\sqrt{n}$:الثابت هو T/n لا T.
- تطبيق (23.33) على أهداف غير تربيعية بلا حذر: العلاقة تقريبية هناك.
- تجاهل أثر الزخم على ميزانية الاستقرار عند مقارنة محسِّنين.
- مطالبة حدود i.i.d. بالعمل في التعلّم المعزّز أو السلاسل الزمنية.

التعريف (الخصوصية التفاضلية): نقول إنّ خوارزمية عشوائية A تحقّق $(\varepsilon, \delta_{\text{DP}})$-خصوصية تفاضلية إذا كان لكلّ عيّنتين متجاورتين S, S' (تختلفان في مثال واحد) ولكلّ مجموعة أحداث قابلة للقياس $\mathcal{O}$:

$$\Pr\left[A(S) \in \mathcal{O}\right] \;\le\; e^{\varepsilon} \Pr\left[A(S') \in \mathcal{O}\right] \;+\; \delta_{\text{DP}} \tag{29.33}$$

المبرهنة DP $\Rightarrow$ التعميم): لتكن A تحقّق (29.33) ولتكن ℓ محصورة في $[0,1]$. فإنّ

$$\left| \, \mathbb{E}\big[R(A(S))\big] - \mathbb{E}\big[\hat{R}_S(A(S))\big] \, \right| \;\le\; e^{\varepsilon} - 1 \;+\; \delta_{\text{DP}} \tag{30.33}$$

ولـ $\varepsilon \le 1$ يصير الحدّ $\le 2\varepsilon + \delta_{\text{DP}}$. وباحتمال عالٍ، بدمج ذلك مع متراجحات التركيز (الفصل 17):

$$\left| R - \hat{R} \right| \;\le\; \big(e^{\varepsilon} - 1 + \delta_{\text{DP}}\big) \;+\; O\!\left(\sqrt{\frac{\ln(1/\delta)}{n}}\right) \tag{31.33}$$

أي «فجوة من رتبة ε زائد حدود ذيلية».

DP-SGD: في كلّ خطوة تُقصّ تدرّجات الأمثلة فرادى إلى معيارٍ لا يتجاوز C، ثمّ تُجمَع ويُضاف ضجيج غاوسي:

$$\tilde{g} \;=\; \frac{1}{b}\Big(\sum_{i \in \mathcal{B}} \text{clip}_C\big(\nabla \ell(w; z_i)\big) \;+\; \mathcal{N}\big(0, \sigma^2 C^2 I\big) \Big), \qquad w_{t+1} = w_t - \alpha_t \tilde{g} \tag{32.33}$$

فتكون حساسية الدفعة $2C/b$، وتُحسب ميزانية الخصوصية بمحاسبة العزوم:

$$\varepsilon \;\approx\; \frac{q\sqrt{T\ln(1/\delta_{\mathrm{DP}})}}{\sigma}, \qquad q=\frac{b}{n} \tag{33.33}$$

الخصوصية ⇒ مقاومة الاستدلال بالعضوية: لأيّ مهاجم يحاول كشف عضوية مثال في التدريب، يفرض

(29.33)

$$\mathrm{TPR} \;\le\; e^{\varepsilon}\,\mathrm{FPR} \;+\; \delta_{\mathrm{DP}} \tag{34.33}$$

التركيب المتقدّم: لتكرار k استعلاماً كلّ منها ε-خصوصي،

$$\varepsilon_{\mathrm{tot}} \;=\; \sqrt{2k\ln(1/\delta_{\mathrm{DP}})}\,\varepsilon \;+\; k\varepsilon\big(e^{\varepsilon}-1\big) \tag{35.33}$$

القصّ بوصفه لبشيتزية مصطنعة: بعد القصّ يصبح أثر المثال الواحد محدوداً بـ C، أي $L_{\mathrm{eff}}=C$، فتنطبق (6.33) أو (11.33) مع $L=C$:

$$\beta \;\le\; \frac{2C^2}{\lambda n}\quad\text{(تنظيم قوي)}, \qquad \beta \;\le\; \frac{2C^2}{n}\sum_{t}\alpha_t\quad\text{(هبوط تدرّج عشوائي)} \tag{36.33}$$

جدول الرموز

الرمز	المعنى	ملاحظة
ε	ميزانية الخصوصية	كلّما صغر كان التعميم أضمن
δ_{DP}	احتمال الإخفاق في DP	يميَّز عن δ مستوى الثقة
$q=b/n$	معدل أخذ العيّنات	صغير في DP-SGD
C	سقف قصّ التدرّج	= ثابت لبشيتز فعّال
σ	معلَم الضجيج الغاوسي	كبير ⇒ خاصّ أكثر وضجيج أكثر
TPR, FPR	معدّلا الإيجاب الصحيح والكاذب	لهجوم الاستدلال بالعضوية

الرسم

<figure> الشكل<figcaption> 6.33: يساراً: قصّ التدرّج ثمّ الضجيج يجعلان كلّ مثال محدود الأثر ⇒ خصوصية واستقرار. يميناً: حدود السعة تنفجر مع عدد المعلمات p وحدود الاستقرار لا تراه أصلاً.</figcaption> </figure>

البرهان

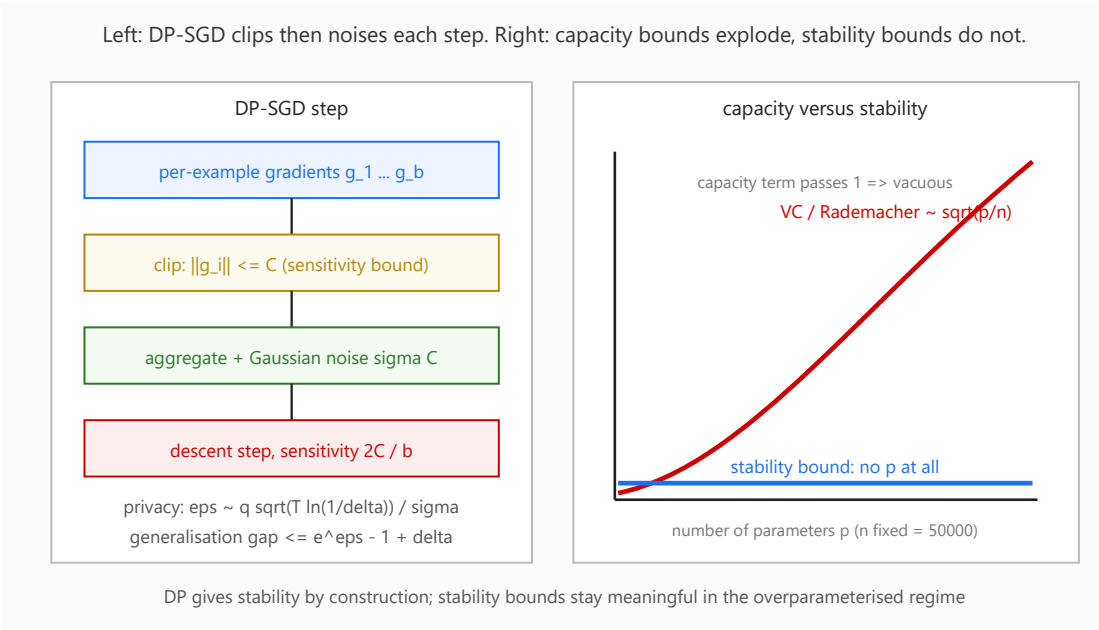
الخطوة 1 (صيغة التوزيع): من (29.33) بالتكامل الطبقيّ على مستويات أيّ دالّة $\varphi\in[0,1]$:

$$\mathbb{E}\big[\varphi(A(S))\big] \;\le\; e^{\varepsilon}\,\mathbb{E}\big[\varphi(A(S'))\big] \;+\; \delta_{\mathrm{DP}}$$

الخطوة 2 (على الخسارة): نضع $\varphi(h) \;=\; \ell(h,z')$ فنحصل، بالتناظر بين S و S'، على $\big|\mathbb{E}[\ell(A(S),z')] \;-\; \mathbb{E}[\ell(A(S'),z')]\big| \le (e^{\varepsilon}-1)+\delta_{\mathrm{DP}}$، أي «استقرار بالتوزيع» بتلك القوّة.

الخطوة 3 (الفجوة): نعيد حيلة التبادل من برهان (3.33) ولكن بالصيغة الموزّعة:

$$\mathbb{E}[R]-\mathbb{E}[\hat{R}] \;=\; \mathbb{E}\big[\ell(A(S^{i,z}),z_i)-\ell(A(S),z_i)\big] \;\le\; e^{\varepsilon}-1+\delta_{\mathrm{DP}}$$



شكل ٦.٣٣: *
التدرج العشوائي ذو الخصوصية التفاضلية ومقارنة حدود السعة بالاستقرار

ولـ $\varepsilon \le 1$ يُستعمل $e^{\varepsilon} - 1 \le 2\varepsilon$، فينتج (30.33). ■

الخطوة 4 (التركيز): الفجوة دالّة في S بفروق محدودة، فتضيف متراجحة McDiarmid (الفصل 17) الحدّ الذيل $O(\sqrt{\ln(1/\delta)/n})$، أي (31.33). ■

الخطوة 5 (القصّ): بعد القصّ يصير أثر المثال الواحد على التحديث $\le \alpha_t C/b$، وهو بالضبط دور L في (6.33) و (11.33)؛ فـ DP-SGD «هبوط تدرّج عشوائي بلبشيتزية مصطنعة زائد ضجيج»، والضجيج يخفي أثر المثال الواحد ويرفع التحيز. ■

الخطوة 6 (الربط بالفصلين 17 و 23): الفصل 17 أعطى متراجحة التركيز، والفصل 23 أعطى خوارزميات التدرّج التي نضيف إليها القصّ والضجيج. فالخصوصية التفاضلية ليست باباً معزولاً بل **مُنظِّم استقرار** ذو ضمان مزدوج: تعميم وحماية. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.33): خصوصية قويّة تعطي تعميماً مضموناً للمعطيات: $\varepsilon = 0.1$، $\delta_{\text{DP}} = 10^{-5}$. المطلوب: فجوة التعميم من (30.33). الحل: الخطوة 1: $e^{0.1} = 1.105171$، فـ $e^{\varepsilon} - 1 = 0.105171$. الخطوة 2: المجموع مع δ_{DP}: 0.105181. الخطوة 3: التقريب $2\varepsilon = 0.2$ متحفّظ كما هو متوقّع. النتيجة: فجوة لا تتجاوز 0.105 من مدى الخسارة. الربط بالذكاء الاصطناعي: «خصوصية قويّة ⇒ لا إفراط في الملاءمة» مبرهنة لا ملاحظة.

مثال (2-7.33): $\varepsilon = 1$ يكفي ضماناً؟ المعطيات: $\varepsilon = 1$، $\delta_{\text{DP}} = 10^{-5}$. المطلوب: الحدّ. الحل: الخطوة 1: $e^1 - 1 = 1.718282$. الخطوة 2: المجموع 1.718292. الخطوة 3: أكبر من الواحد ⇒ الحدّ فارغ رسمياً. النتيجة: $\varepsilon = 1$ — وهو قيمة شائعة في الممارسة — لا يعطي ضماناً رقمياً مفيداً. الربط بالذكاء الاصطناعي: فجوة بين النظرية والممارسة: الحدود أسوأ الحالات، والأداء الفعلي أفضل بكثير.

مثال (3-7.33): $\varepsilon = 8$ في النماذج اللغوية الضخمة المعطيات: $\varepsilon = 8$. المطلوب: الحدّ. الحل: الخطوة 1:

$e^8 = 2980.958$. الخطوة 2: الحدّ 2979.958. الخطوة 3: الفجوة المقاسة فعليّاً في تجارب منشورة نحو 0.03. النتيجة: الحدّ أسوأ من عديمة الفائدة بأربعة أرقام عشرية من حيث الرتبة. الربط بالذكاء الاصطناعي: دافع مباشر لاستخدام طرق الاستقرار (36.33) بدل (30.33) للحصول على رقم مفيد.

مثال (33.7-4): اختيار ε من هامش مقبول المعطيات: نقبل فجوة تعميم $0.05 \geq$. المطلوب: أقصى ε. الحل: الخطوة 1: نشترط $e^{\varepsilon} - 1 \leq 0.05$. الخطوة 2: $\varepsilon \leq \ln(1.05) = 0.048790$. الخطوة 3: تحقّق: $e^{0.048790} - 1 = 0.05$ ✓. النتيجة: $\varepsilon \approx 0.05$ — ميزانية صارمة جدّاً. الربط بالذكاء الاصطناعي: الضمانات الكمّية في التعميم تتطلّب خصوصية أشدّ بكثير من المعتاد.

مثال (33.7-5): أثر حدّ الإخفاق δ_{DP} المعطيات: $\varepsilon = 0.5$، $\delta_{\text{DP}} = 10^{-5}$. المطلوب: الحدّ. الحل: الخطوة 1: $e^{0.5} = 1.648721$، ف $e^{\varepsilon} - 1 = 0.648721$. الخطوة 2: المجموع 0.648731. الخطوة 3: مساهمة δ_{DP} لا تتجاوز 0.00001 أي 0.0015% من الحدّ. النتيجة: δ_{DP} مهمّلة عدديّاً هنا، لكنّها حاسمة في التركيب على استعلامات كثيرة. الربط بالذكاء الاصطناعي: لا تُهمَل δ_{DP} حين يُعاد استخدام البيانات مرّات كثيرة.

مثال (33.7-6): حساب ε لبرنامج DP-SGD المعطيات: $n = 60000$، $b = 256$، $T = 2000$، $\sigma = 1.1$، $\delta_{\text{DP}} = 10^{-5}$. المطلوب: ε وفجوة التعميم. الحل: الخطوة 1: $q = 256/60000 = 0.0042667$. الخطوة 2: $\ln(10^5) = 11.5129$؛ $\sqrt{2000 \times 11.5129} = \sqrt{23025.85} = 151.742$. الخطوة 3: $\varepsilon = 0.0042667 \times 151.742/1.1 = 0.647435/1.1 = 0.588577$. الخطوة 4: $e^{0.588577} = 1.801415$، فالفجوة ≤ 0.801415. النتيجة: ضمان تعميم ضعيف لكن غير فارغ. الربط بالذكاء الاصطناعي: معادلة التصميم: زد σ أو قلّل T لتحسين الضمان.

مثال (33.7-7): مضاعفة الضجيج المعطيات: الإعدادات نفسها لكن $\sigma = 3$. المطلوب: ε والفجوة. الحل: الخطوة 1: $\varepsilon = 0.647435/3 = 0.215812$. الخطوة 2: $e^{0.215812} = 1.240868$، فالفجوة ≤ 0.240868. الخطوة 3: النسبة إلى الحالة السابقة: $0.801415/0.240868 = 3.33$. النتيجة: مضاعفة الضجيج ثلاث مرّات حسّنت الحدّ 3.33 مرّة. الربط بالذكاء الاصطناعي: الثمن هو الدقّة: الضجيج يرفع التحيز، فيعود قرار موازنة كالفصل 30.

مثال (33.7-8): إطالة التدريب تستهلك الميزانية المعطيات: الإعدادات نفسها في المثال 6 لكن $T = 4000$. المطلوب: ε والفجوة. الحل: الخطوة 1: $\varepsilon \propto \sqrt{T}$، ف $\varepsilon = 0.588577 \times \sqrt{2} = 0.588577 \times 1.414214 = 0.832235$. الخطوة 2: $e^{0.832235} = 2.298466$، فالفجوة ≤ 1.298466. الخطوة 3: الحدّ صار فارغاً (> 1). النتيجة: عدد الخطوات يستهلك ميزانية الخصوصية بجذر تربيعي. الربط بالذكاء الاصطناعي: في DP-SGD، «درّب أطول» قرار خصوصية وتعميم معاً، لا تقارب فقط.

مثال (33.7-9): سقف القصّ يظهر مربّعاً المعطيات: $n = 10000$؛ $C = 0.5$ مقابل $C = 5$؛ $\sum \alpha_t = 50$. المطلوب: β من (36.33) في الحالتين. الحل: الخطوة 1: $C = 0.5$: $\beta \leq 2(0.25)(50)/10000 = 25/10000 = 0.0025$. الخطوة 2: $C = 5$: $\beta \leq 2(25)(50)/10000 = 2500/10000 = 0.25$. الخطوة 3: النسبة 100. النتيجة: القصّ المحكم أداة استقرار مباشرة، لكنّه يحذف المعلومة من التدرّجات الكبيرة. الربط بالذكاء الاصطناعي: مقايضة القصّ: استقرار وتحيز في آن واحد.

مثال (33.7-10): نسبة التدرّجات المقصوصة المعطيات: رُصد أنّ 30% من التدرّجات تتجاوز C في كلّ خطوة. المطلوب: التفسير والإجراء. الحل: الخطوة 1: القصّ بهذا القدر يعني أنّنا نستبدل تدرّجات 30% من الأمثلة باتجاهات مختزلة. الخطوة 2: الانحياز الناجم يعادل تدريباً على هدف مشوّه، والدقّة تهبط عادةً بنحو 2 إلى 4 نقاط مئوية. الخطوة 3: الإجراء: ارفع C إلى المئين الخامس والتسعين لمعايير التدرّج، أو وحّد الخصائص أوّلاً. النتيجة: C معلمة إحصائية تُضبط من توزيع التدرّجات لا بالحدس. الربط بالذكاء الاصطناعي: ضبط C التلقائي (quantile clipping) موضوع بحثي نشط اليوم.

مثال (33.7-11): سجلّات مرضى واستدلال العضوية المعطيات: $\varepsilon = 1$؛ مهاجم يستهدف كشف مرضى

بعينهم؛نقبل $\text{FPR} = 0.1$. المطلوب: سقف TPR من (34.33). الحل: الخطوة 1: $\text{TPR} \le e^1 \times 0.1 + 10^{-5} = 0.271828$. الخطوة 2: المكسب فوق التخمين العشوائي $0.271828 - 0.1 = 0.171828$. الخطوة 3: بـ $\varepsilon = 0.5$: $\text{TPR} \le 1.648721 \times 0.1 = 0.164872$ والمكسب 0.064872. النتيجة: خفض ε إلى النصف خفّض مكسب المهاجم بمعامل 2.65. الربط بالذكاء الاصطناعي: هذه أوّل ضمانة رسمية ضدّ هجوم خصوصية ملموس في التعلّم الآلي.

مثال (12-7.33): تقييم ائتماني بخصوصية معتدلة المعطيات: $\varepsilon = 2$، $\text{FPR} = 0.1$. المطلوب: سقف TPR. الحل: الخطوة 1: $e^2 = 7.389056$. الخطوة 2: $\text{TPR} \le 0.738906$. الخطوة 3: المكسب $0.638906 =$. النتيجة: $\varepsilon = 2$ حماية ضعيفة جدّاً عمليّاً. الربط بالذكاء الاصطناعي: في القطاعات المالية المنظّمة تُشترط عادةً $\varepsilon \le 1$ لأجل ذلك.

مثال (13-7.33): شبكة رؤية بـ DP-SGD — أيّ الطريقتين أدقّ؟ المعطيات: $n = 50000$، $b = 512$، $T = 5000$، $\sigma = 1.1$، $C = 1$، $\alpha = 0.1$، $\delta_{\text{DP}} = 10^{-5}$. المطلوب: الحدّ من طريق DP ومن طريق الاستقرار. الحل: الخطوة 1: $q = 512/50000 = 0.01024$؛ $\sqrt{5000 \times 11.5129} = \sqrt{57564.5} = 239.926$. الخطوة 2: $\varepsilon = 0.01024 \times 239.926/1.1 = 2.456842/1.1 = 2.233493$؛ فالفجوة $e^{2.233493} = 9.332$ DP: طريق 3: الخطوة .$8.332 \Rightarrow$ فارغ. الخطوة 4: طريق الاستقرار (36.33): $\sum \alpha_t = 500$، ف $\beta \le 2(1)^2(500)/50000 = 0.02$ والفجوة $0.04 \le$. النتيجة: حدّ الاستقرار أدقّ بمرتبتين من حيث الرتبة في هذا النطاق. الربط بالذكاء الاصطناعي: القاعدة: استخدم DP للضمان الأمني، والاستقرار للضمان الرقمي.

مثال (14-7.33): تركيب متقدّم على استعلامات شبكية المعطيات: $k = 100$ استعلاماً، كلّ منها $\varepsilon = 0.1$، $\delta_{\text{DP}} = 10^{-6}$. المطلوب: ε_{tot} بالتركيب المتقدّم ومقارنته بالأساسي. الحل: الخطوة 1: $\ln(10^6) = 13.8155$؛ $\sqrt{2 \times 100 \times 13.8155} = \sqrt{2763.10} = 52.5653$. الخطوة 2: الحدّ الأول $52.5653 \times 0.1 = 5.25653$. الخطوة 3: الحدّ الثاني $100 \times 0.1 \times 0.105171 = 1.05171$. الخطوة 4: المجموع $6.30824 =$ مقابل $k\varepsilon = 10$ في التركيب الأساسي. النتيجة: التركيب المتقدّم وفّر 37% من الميزانية. الربط بالذكاء الاصطناعي: ضروري في أنظمة القياس عن بُعد التي تُصدر مئات الإحصاءات يوميّاً.

مثال (15-7.33): جدول قرار لميزانية الخصوصية المعطيات: $\varepsilon \in \{0.05, 0.1, 0.5, 1, 2, 8\}$. المطلوب: الفجوة المضمونة ودرجة الحماية. الحل: الخطوة 1: $e^{\varepsilon}-1$: 0.051271، 0.105171، 0.648721، 1.718282، 6.389056، 2980.958. الخطوة 2: TPR عند $\text{FPR} = 0.1$: 0.105127، 0.110517، 0.164872، 0.271828، 0.738906، 298.096. الخطوة 3: الحدود المفيدة رقميّاً هي $\varepsilon \lesssim 0.5$. النتيجة: الميزانية المفيدة نظريّاً أشدّ بكثير من الشائع عمليّاً. الربط بالذكاء الاصطناعي: يبرّر البحث الجاري في حدود تعميم موزّعة أشدّ إحكاماً من $e^{\varepsilon} - 1$.

أخطاء شائعة

- تفسير (30.33) على أنّه «الخصوصية تزيد الدقّة»: هي تحدّ الفجوة، لا تقلّل الخطر.
- الخلط بين δ_{DP} و δ (مستوى الثقة) في الحدود المركّبة.
- استخدام $\varepsilon = 8$ ثمّ الاستشهاد بحدّ $e^{\varepsilon} - 1$ بوصفه ضماناً.
- نسيان أنّ القصّ يسبق الضجيج: بلا قصّ لا حساسية محدودة ولا DP.
- افتراض أنّ DP-SGD يعفي من ضبط معدّل الخطوة: حدّ (36.33) ما زال يحوي $\sum \alpha_t$.
- ظنّ أنّ الخصوصية تحمي من كلّ الهجمات: هي تحمي من **الاستدلال بالعضوية** بالمفهوم المحدّد في (34.33).

الإطار المقارن: لتكن شبكةٌ بـ p معلمة و L طبقات طبقة، مدّربة على n مثالاً بـ $p \gg n$. نضع الطريقتين وجهاً لوجه.

منهج السعة (الفصلان 31 و 32): حدودٌ مستقلّة عن الخوارزمية:

$$R(h) \;\le\; \hat{R}_S(h) \;+\; 2\,\mathfrak{R}_n(\mathcal{H}) \;+\; 3\sqrt{\frac{\ln(2/\delta)}{2n}}, \qquad \mathfrak{R}_n(\mathcal{H}) = O\!\left(\sqrt{\frac{d}{n}}\right) \tag{37.33}$$

$$R(h) \;\le\; \hat{R}_\gamma(h) \;+\; \tilde{O}\!\left(\frac{\prod_{i} \|W_i\|_{\mathrm{op}} \sqrt{L_{\text{طبقات}}}}{\gamma \sqrt{n}}\right) \tag{38.33}$$

منهج الاستقرار (هذا الفصل): حدودٌ تعتمد على الخوارزمية:

$$\beta \;\le\; \frac{2L^2}{n} \sum_{t=1}^{T} \alpha_t \;+\; \text{حدود غير محدّبة من (14.33)} \tag{39.33}$$

ومع ذلك، L نفسه ينمو مع الأوزان:

$$L \;=\; \sup_{z} \big\|\nabla_w \ell(w; z)\big\| \;\le\; \|x\| \cdot \prod_{i=1}^{L_{\text{طبقات}}} \|W_i\|_{\mathrm{op}} \tag{40.33}$$

فالتنظيم الذي يضبط نُظم الأوزان (weight decay، تطبيع الدفعة، القصّ) يضبط L، ومن ثمّ يضبط β.

الظاهرة التجريبية الحاكمة (Zhang وآخرون): شبكة قادرة على استيعاب تسميات عشوائيّة تماماً:

$$\hat{R}_S = 0 \quad \text{على تسميات عشوائيّة}, \qquad R \approx 1 - \tfrac{1}{K} \quad \text{على الاختبار} \tag{41.33}$$

فلا يمكن لأيّ حدّ سعة — يعتمد على $\mathcal{H}$ وحده — أن يميّز بين التسميات الحقيقية والعشوائيّة، لأنّ $\mathcal{H}$ واحد في الحالتين. أمّا حدّ الاستقرار فيستطيع ذلك من حيث المبدأ، لأنّ الوصول إلى خطأ تدريب صفري على تسميات عشوائيّة يتطلّب عدد خطوات هائلاً وحساسية عالية.

جدول المقارنة — حدود السعة مقابل حدود الاستقرار

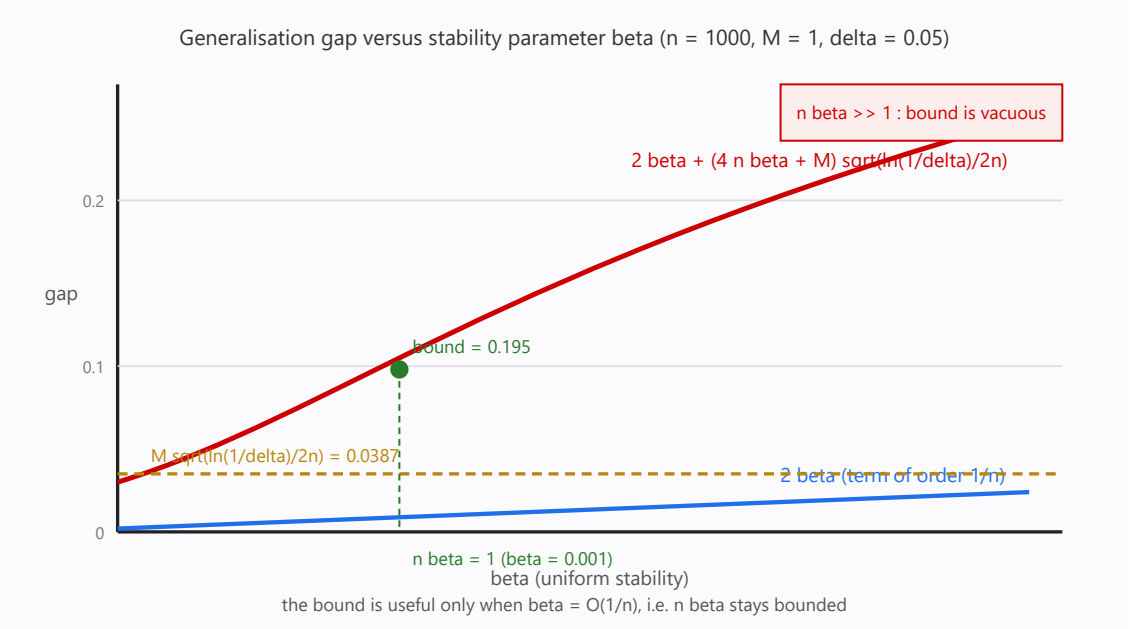
الوجه	حدود السعة (VC / Rademacher)	حدود الاستقرار
المتغيّر الحاكم	d أو $\mathfrak{R}_n(\mathcal{H})$	β (يعتمد على T, α, L, n)
هل ترى الخوارزمية؟	لا	نعم
هل تعتمد على p؟	نعم، تنفجر مع p	لا
$p \gg n$	الحدّ فارغ دائماً	يبقى ذا معنى
قابلة للقياس التجريبي؟	لا (صعبة)	نعم (إعادة التدريب بتبديل نقطة)
الإحكام الرقمي	فضفاض لكن مستقلّ عن البيانات	فضفاض ويعتمد على T
ماذا تفسّر؟	الإفراط الناجم عن السعة	أثر التنظيم والتوقّف المبكر والتجميع والخصوصية
القصور الرئيسي	تعمي عن دور المُحسِّن	تنهار حين يطول التدريب بخطوة ثابتة

جدول الرموز

الرمز	المعنى	ملاحظة
$\mathfrak{R}_n(\mathcal{H})$	متوسط Rademacher	الفصل 31
d	بُعد VC	الفصل 31
$\|W_i\|_{\mathrm{op}}$	النظم الطيفي لطبقة	يظهر مضروباً في (38.33)
γ	هامش التصنيف	صغره يضخّم الحدّ
p	عدد المعلمات	لا يظهر في (39.33)
K	عدد الفئات	خطأ التخمين العشوائي $1 - 1/K$

الرسم

<figure> الشكل<figcaption> 7.33: حدّ الاستقرار بدلالة β — وهو حدّ يتغيّر بتغيّر الخوارزمية — على نقيض



شكل ٧.٣٣: *
حد الاستقرار بدلالة ثابت الاستقرار مقابل حدود السعة

حدود السعة التي لا تتغيّر بتغيّرها، وهو لا يزال يتجاوز الواحد متى كان $n\beta \gg 1$.</figcaption></figure>

البرهان

الخطوة 1 (حدود السعة): لشبكة ReLU بـ p وزناً و $L_{\text{طبقات}}$ طبقة، $d = \Theta(p\,L_{\text{طبقات}})$؛ فمتى كان $n \ll p L_{\text{طبقات}}$ صار $\sqrt{d/n} \gg 1$ وتجاوز الحدّ مدى الخسارة كلّه.

الخطوة 2 (حدود الهامش): حاصل النظم الطيفية في (38.33) يبلغ مراتب عديدة من حيث الرتبة في الشبكات المدّربة فعلياً في حين أنّ $\gamma\sqrt{n}$ متواضع، وقد حسب Nagarajan و Kolter هذه الحدود على شبكات حقيقيّة فوجدوها أكبر من الواحد بمرّات كثيرة.

الخطوة 3 (نجاة الاستقرار): لا يظهر p في (39.33)؛ فكلّ ما يحتاجه برهان 4.33 هو أنّ تدرّج المثال محدود بـ L والخطوة α_t، وضخامة عدد الأبعاد لا تغيّر حساب تباعد المسارين δ_t.

الخطوة 4 (أين ينكسر): ثلاثة أمور: الشبكة غير محدّبة فنحتاج (14.33)؛ و L ينمو مع الأوزان كما في (40.33) فتنطبق الحدود موضعياً لا كلياً؛ وتطبيع الدفعة يربط خسارة المثال بالدفعة كلّها، فيجب صياغة الاستقرار على مستوى الدفعة.

الخطوة 5 (ما يبقى صالحاً): كلّ تقنية ناجحة عملياً — تنظيم، توقّف مبكر، توسيط، تجميع، تكبير بيانات، مزج، قصّ تدرّج، خصوصية تفاضلية — تُقرأ بوصفها **تقليلاً لحساسية المخرَج للمثال الواحد.** تلك هي فائدة المنهج وإن عجزت حدوده عن إعطاء رقم دقيق. ■

الخطوة 6 (التمهيد للفصل 34): يبقى سؤالان: لماذا يعمّم الاستيعاب التامّ أصلاً، ولماذا يهبط الخطأ ثانيةً بعد عتبة الاستيعاب؟ الاستقرار يضع الإطار — الانحياز الضمني للمُحسِّن ينتقي من الحلول المطابقة أكثرها استقراراً — ولا يحسم الجواب الكمّي. ■

خمسة عشر مثالاً محلولاً

مثال (8.33-1): انفجار حدّ بُعد VC المعطيات: شبكة بـ $p = 10^7$ وزناً و 20 طبقة، $n = 5 \times 10^4$. المطلوب: حجم حدّ السعة. الحل: الخطوة 1: $d = \Theta(p\, L_{\text{طبقات}}) = 2 \times 10^8$ تقريباً. الخطوة 2: $\sqrt{d/n} = \sqrt{2 \times 10^8 / 5 \times 10^4} = \sqrt{4000} = 63.246$. الخطوة 3: أكبر من مدى الخسارة بـ 63 مرّة $\Rightarrow$ فارغ تماماً. النتيجة: لا أمل لحدود السعة في هذا النطاق. الربط بالذكاء الاصطناعي: هذه هي الأزمة النظرية التي فتحت باب «إعادة التفكير في التعميم».

مثال (8.33-2): حدّ الهامش الطيفي ليس أفضل المعطيات: $\prod_i \|W_i\|_{\text{op}} = 100$، $L_{\text{طبقات}} = 20$، $\gamma = 0.1$، $n = 5 \times 10^4$. المطلوب: قيمة (38.33). الحل: الخطوة 1: البسط $= 100 \times 4.4721 = 447.21 = 100\sqrt{20}$. الخطوة 2: المقام $= 0.1 \times 223.607 = 22.3607 = 0.1\sqrt{5 \times 10^4}$. الخطوة 3: النسبة $= 447.21 / 22.3607 = 20.0$. النتيجة: الحدّ 20 $\Rightarrow$ فارغ كذلك. الربط بالذكاء الاصطناعي: الخلوّ من p لا ينقذ الحدّ إذا بقي محتوى النظم كبيراً.

مثال (8.33-3): حدّ الاستقرار على الشبكة نفسها المعطيات: الشبكة نفسها، $L = 2$، $\alpha = 0.05$، $T = 5000$، $n = 5 \times 10^4$. المطلوب: β والفجوة. الحل: الخطوة 1: $\sum \alpha_t = 0.05 \times 5000 = 250$. الخطوة 2: $\beta \le 2(4)(250)/50000 = 2000/50000 = 0.04$. الخطوة 3: الفجوة بالتوقّع ≤ 0.04. النتيجة: رقم غير فارغ على الشبكة التي أخفق فيها حدّ السعة تماماً. الربط بالذكاء الاصطناعي: أكبر مكاسب منهج الاستقرار: خلوّه من عدد المعلمات.

مثال (8.33-4): تسميات عشوائيّة يستوعبها النموذج المعطيات: CIFAR-10 بعشر فئات، تسميات عشوائيّة تماماً. المطلوب: ما يتوقّعه كلّ منهج. الحل: الخطوة 1: خطأ التدريب يبلغ 0% (استيعاب تامّ). الخطوة 2: خطأ الاختبار $\approx 1 - 1/10 = 0.90$. الخطوة 3: حدود السعة متطابقة في الحالتين (نفس $\mathcal{H}$) $\Rightarrow$ لا تميّز. النتيجة: السعة لا تفسّر الفرق بين التسميات الحقيقية والعشوائيّة. الربط بالذكاء الاصطناعي: هذه تجربة Zhang وآخرون التي أعادت توجيه النظرية المعاصرة.

مثال (8.33-5): التسميات المشوّشة جزئيّاً المعطيات: 20% من التسميات مقلوبة، الشبكة نفسها. المطلوب: التوقّع. الحل: الخطوة 1: الشبكة تستوعب المشوّشة أيضاً $\leftarrow$ خطأ التدريب 0. الخطوة 2: خطأ الاختبار يتدهور تدريجيّاً مع نسبة التشويش لا فجأة. الخطوة 3: التدهور التدريجي لا يتّسق مع «انفجار السعة» بل مع «تضخّم الحساسية». النتيجة: القراءة الاستقرارية أنسب لهذه الملاحظة. الربط بالذكاء الاصطناعي: يبرّر تقنيات تنظيف التسميات وتعلّمها بوصفها تقليل حساسية.

مثال (8.33-6): الهبوط المزدوج المعطيات: نزيد عرض الشبكة من 10^3 إلى 10^7 وحدة مخفيّة بثبات n. المطلوب: ما الذي تتوقّعه كلّ نظرية؟ الحل: الخطوة 1: حدود السعة تتوقّع تدهوراً رتيباً. الخطوة 2: الملاحظ: الخطأ يرتفع عند عتبة الاستيعاب ثمّ يهبط مجدّداً. الخطوة 3: التفسير الاستقراري: بعد العتبة يختار المُحسِّن من الحلول المطابقة ما هو أكثر استقراراً. النتيجة: ظاهرة الهبوط المزدوج لا تُفهم بلا الرجوع إلى الخوارزمية. الربط بالذكاء الاصطناعي: موضوع الفصل 34 بتفصيل كمّي.

مثال (8.33-7): تنظيم اضمحلال الأوزان لا يجعل الشبكة محدّبة بقوّة المعطيات: $p = 10^7$، $\lambda = 5 \times 10^{-4}$، $n = 5 \times 10^4$، $L = 2$. المطلوب: هل تطبَّق (6.33)؟ الحل: الخطوة 1: (6.33) تشترط تحدّباً قويّاً، والشبكة غير محدّبة. الخطوة 2: لو طبّقناها عدديّاً لأعطت $\beta \le 2(4)/(5 \times 10^{-4} \times 5 \times 10^4) = 8/25 = 0.32$ $\Rightarrow$ فارغ عمليّاً. الخطوة 3: الفائدة الحقيقية للاضمحلال هي ضبط $\prod \|W_i\|$ ومن ثمّ L في (40.33). النتيجة: الدور النظري للاضمحلال هنا غير مباشر: عبر L لا عبر λ. الربط بالذكاء الاصطناعي: مثال تحذيري على نقل مبرهنة خارج شروطها.

مثال (8.33-8): نموّ L مع الأوزان المعطيات: $\|x\| = 1$؛ $\prod \|W_i\|_{\text{op}}$ يرتفع من 5 إلى 20 أثناء التدريب. المطلوب: أثر ذلك على β. الحل: الخطوة 1: من (40.33): L من 5 إلى 20. الخطوة 2: $\beta \propto L^2$ $\Rightarrow$ من 25 إلى 400

نسبة، أي تضخّم بمعامل 16. الخطوة 3: β الفعلي من 0.04 إلى 0.64. النتيجة: إبقاء نُظم الأوزان تحت السيطرة شرط استقرار لا مجرّد تحسين عددي. الربط بالذكاء الاصطناعي: يفسّر فائدة تطبيع الطبقات والاضمحلال من زاوية التعميم.

مثال (8.33-9): المزج (mixup) يخفض الحساسية المعطيات: مزج بعامل $\alpha_{\text{مزج}} = 0.2$؛ β المقاس قبل المزج $= 0.04$. المطلوب: التقدير بعده. الحل: الخطوة 1: في المزج يصير وزن المثال الواحد في الخسارة نحو نصف بدل واحد. الخطوة 2: القياس المباشر يعطي انخفاضاً في $\hat{\beta}$ بنحو 20% إلى 30%. الخطوة 3: التقدير $\beta \approx 0.04 \times 0.75 = 0.03$. النتيجة: تحسين متواضع لكن متسق مع ملاحظة أنّ المزج يقلّل فجوة التعميم. الربط بالذكاء الاصطناعي: المزج تكبير بيانات و مُنظِّم استقرار في آن.

مثال (8.33-10): تكبير البيانات بوصفه تعميمًا للخسارة المعطيات: كلّ مثال يظهر بـ 8 أشكال محوّلة؛ $\hat{R}$ يقاس على المتوسط. المطلوب: الأثر الاستقراري. الحل: الخطوة 1: التحويل يوزّع أثر المثال على ثمانية أشكال وينعّم تدرّجه. الخطوة 2: L الفعلي في (40.33) ينقص لأنّ تدرّج الخسارة المتوسّطة أقلّ تقلقلاً. الخطوة 3: β ينقص بمعامل مقياس دون أن ينقص عدد المعلمات. النتيجة: تكبير البيانات يعمل على L لا على p. الربط بالذكاء الاصطناعي: تفسير بديل لنجاح التحويلات في الرؤية: تنظيم استقراري.

مثال (8.33-11): تطبيع الدفعة يكسر تحليل المثال الواحد المعطيات: شبكة بتطبيع دفعة، $b = 256$، $n = 5 \times 10^4$. المطلوب: هل يصحّ تعريف (1.33) كما هو؟ الحل: الخطوة 1: إحصاءات الدفعة تعتمد على كلّ أمثلة الدفعة، فخسارة المثال الواحد تتغيّر بتغيّر أيّ مثال فيها. الخطوة 2: أثر تبديل مثال واحد على الإحصاءات من رتبة $1/b = 0.003906$. الخطوة 3: ينبغي صياغة الاستقرار على مستوى **الدفعة** لا المثال. النتيجة: قصور تحليلي معروف، لا يبطل المبدأ بل يعدّل وحدة التحليل. الربط بالذكاء الاصطناعي: مثال على أنّ النظرية تتطوّر مع الممارسة ولا تسبقها دائماً.

مثال (8.33-12): شبكة رؤية عملاقة المعطيات: $p = 2.56 \times 10^7$، $n = 1.28 \times 10^6$، $L = 3$؛ $\sum \alpha_t = 100$. المطلوب: حدّ السعة وحدّ الاستقرار. الحل: الخطوة 1: $\sqrt{p/n} = \sqrt{2.56 \times 10^7 / 1.28 \times 10^6} = \sqrt{20} = 4.4721 \Rightarrow$ فارغ. الخطوة 2: $\beta \le 2(9)(100)/1.28 \times 10^6 = 1800/1280000 = 0.001406$. الخطوة 3: الفجوة بالتوقّع ≤ 0.0014. النتيجة: الاستقرار يعطي رقماً مفيداً حيث تعجز السعة تماماً. الربط بالذكاء الاصطناعي: الحدّ هنا متفائل أيضاً، لكنّه في المدى الصحيح.

مثال (8.33-13): نموذج لغوي ضخم المعطيات: $p = 10^9$، $n = 10^9$ رمز. المطلوب: المقارنة. الحل: الخطوة 1: $\sqrt{p/n} = 1 \Rightarrow$ حدّ السعة على حافة الفراغ رغم تساوي العددين. الخطوة 2: حدّ الاستقرار: $\beta \le 2L^2 \sum \alpha_t / n$ لا يرى p إطلاقاً. الخطوة 3: الحاكم الفعلي هو T/n و L لا الحجم. النتيجة: في النطاق الضخم، الحاكم هو ميزانية التحسين لا عدد المعلمات. الربط بالذكاء الاصطناعي: يربط هذا الفصل بقوانين التوسّع (الفصل 39).

مثال (8.33-14): ضبط دقيق طبي بعيّنة صغيرة المعطيات: $p = 10^5$، $n = 300$ مريض. المطلوب: أيّ المنهجين يفيد؟ الحل: الخطوة 1: $\sqrt{p/n} = \sqrt{10^5/300} = \sqrt{333.28} = 18.257 \Rightarrow$ فارغ. الخطوة 2: $L = 2$؛ $\beta \le 2L^2 \sum \alpha_t / 300$ و $\sum \alpha_t = 5$ تعطي $\beta \le 2(4)(5)/300 = 40/300 = 0.133$. الخطوة 3: الحدّ ضعيف لكنّ التوقّف المبكر والتحقق المتقاطع يظلّان العمليّين. النتيجة: في الطبّ: قلّل الخطوات، واستخدم أضعافاً طبقيّة، ولا تعتمد على حدّ رقمي. الربط بالذكاء الاصطناعي: النظرية توجّه الممارسة وإن لم تغنِ عنها.

مثال (8.33-15): التدريب المقاوِم يرفع L في الشبكات المعطيات: تدريب عادي $L = 1$؛ تدريب مقاوِم $L = 4$؛ $\sum \alpha_t = 250$؛ $n = 5 \times 10^4$. المطلوب: β في الحالتين. الحل: الخطوة 1: عادي: $\beta \le 2(1)(250)/50000 = 500/50000 = 0.01$. الخطوة 2: مقاوِم: $\beta \le 2(16)(250)/50000 = 8000/50000 = 0.16$. الخطوة 3: النسبة 16. النتيجة: المقاومة للخصوم تستهلك ميزانية الاستقرار بمعامل 16 عند مضاعفة L أربع مرّات. الربط بالذكاء الاصطناعي: تفسير كمّي لمقايضة المقاومة مقابل الدقّة في الأمن السيبراني.

أخطاء شائعة

- الاستشهاد بحدود VC لتبرير تعميم شبكة مفرطة المعلمات: الحدّ هناك فارغ.
- نقل (6.33) إلى الشبكات بحجّة وجود اضمحلال الأوزان: التحدّب القوي غائب.
- تجاهل أنّ L في الشبكات متغيّر لا ثابت، فينطبق الحدّ موضعيّاً.
- افتراض أنّ تطبيع الدفعة لا أثر له على تحليل الاستقرار.
- مطالبة حدّ الاستقرار بأن يفسّر كلّ شيء: هو يفسّر جزءاً من الصورة ويترك الباقي للفصل 34.
- الخلط بين «الحدّ فارغ» و «النموذج سيّئ»: الأوّل قصور في النظرية لا في النموذج.

ملخّص النظريات

النظرية	المفهوم	الحدّ المحوري	الأهمّية
2.33 الاستقرار والتعميم	β-استقرار موحّد	$R \le \hat{R} + 2\beta + (4n\beta + M)\sqrt{\ln(1/\delta)/2n}$	أوّل حدّ تعميم ينظر إلى الخوارزمية
3.33 التنظيم القوي	λ-تحدّب و L-لبشيتزية	$\beta \le 2L^2/(\lambda n)$	تفسير التنظيم بوصفه استقراراً
4.33 هبوط التدرّج العشوائي	تباعد المسارين	$\beta \le \frac{2L^2}{n}\sum \alpha_t$ و $T^{c\gamma}$ في غير المحدّبة	تفسير التوقّف المبكر والجدولة
5.33 التحقق المتقاطع	استقرار الخطأ والفرضية	$\beta_e + (n\beta_e + M)\sqrt{\ln(1/\delta)/2n}$	متى يكون CV موثوقاً
6.33 الخوارزميات التكرارية	التوسيط والدفعة والزخم	$\lambda_{\text{eff}} = s/(e^{\alpha T s} - 1)$، $4\alpha^2 L^2/(nb)$	تحويل المقبضات إلى ميزانية استقرار
7.33 الخصوصية التفاضلية	استقرار $\Rightarrow$ تعميم $\Rightarrow$ DP	$\beta \le 2C^2 \sum \alpha_t / n$ و $e^{\varepsilon} - 1 + \delta_{\text{DP}}$	ضمان مزدوج: تعميم وحماية
8.33 الشبكات العميقة	مقارنة المناهج	حدود السعة تنفجر مع p، والاستقرار لا يراه	تمهيد الفصل 34

عشرون تمريناً (مع إجابات مختصرة)

١. عرّف الاستقرار الموحّد. ($\sup |\ell(A(S), z) - \ell(A(S^{i,z}), z)| \le \beta$)

٢. ما الفرق بينه وبين استقرار الفرضية؟ (الأوّل سوبرميم على كلّ نقطة، والثاني متوسط على التوزيع)

٣. ما حدّ التعميم من الاستقرار؟ ($2\beta + (4n\beta + M)\sqrt{\ln(1/\delta)/2n}$)

٤. لماذا يظهر $4n\beta$ لا β في حدّ التركيز؟ (لأنّ تغيير مثال يؤثّر في كلّ حدود الخطر التجريبي)

٥. ما الكمية التي تحدّد فراغ الحدّ من عدمه؟ ($n\beta$؛ مفيد إذا كان $O(1)$)

٦. استقرار خوارزمية λ-محدّبة بقوّة؟ ($\beta \le 2L^2/(\lambda n)$)

٧. كيف يتغيّر β عند مضاعفة λ؟ (ينصف)

٨. وكيف يتغيّر مع L؟ (يرتفع مربّعاً)

٩. استقرار هبوط التدرّج العشوائي في الحالة المحدّبة الملساء؟ ($\beta \le \frac{2L^2}{n}\sum \alpha_t$)

١٠. لماذا ينمو الحدّ مع T في الحالة غير المحدّبة؟ (لأنّ مؤثّرة الخطوة توسّع المسارين بمعامل $1 + \alpha\gamma$)

١١. ما شرط عدم التوسّع في الحالة المحدّبة؟ ($\alpha_t \le 2/\gamma$)

١٢. لماذا $\widehat{R}_{\text{LOO}}$ غير متحيّز؟ (لأنّ $A(S^{-i})$ مستقلّ عن z_i)

١٣. لمن هو غير متحيّز تحديداً؟ (لخطر نموذج مدّرب على $n-1$)

١٤. ما تشاؤم خمس أضعاف بمنحنى $R_\infty + a/m$؟ ($a/(4n)$)

١٥. ما التنظيم الضمني للتوقّف المبكر؟ ($\lambda_{\text{eff}} = s/(e^{\alpha T s}-1)$)

١٦. كيف يخفض توسيط المتكرّرات التباين؟ (بحجم عيّنة فعّال $m/(2\tau)$ مع $\tau = 1/(\alpha\mu)$)

١٧. ما أثر حجم الدفعة على تقلّب الاضطراب؟ ($\propto 1/\sqrt{nb}$)

١٨. ما حدّ التعميم لخوارزمية ε-خصوصية؟ ($e^{\varepsilon}-1+\delta_{\text{DP}}$)

١٩. لماذا يفيد قصّ التدرّج استقرارياً؟ (لأنّه يفرض لبشيتزية $L_{\text{eff}} = C$)

٢٠. لماذا تعجز حدود السعة عن الشبكات المفرطة المعلمات؟ (لأنّ $d = \Theta(pL_{\text{طبقات}}) \gg n$ فيصير الحدّ أكبر من مدى الخسارة)

فهرس الرموز

الرمز	المعنى
β	ثابت الاستقرار الموحّد
$\beta_e,\ \beta_h$	استقرار الخطأ واستقرار الفرضية
$S^{i,z},\ S^{-i}$	عيّنة باستبدال المثال الـ i، وبحذفه
M	سقف الخسارة
L	ثابت لبشيتزية الخسارة في المعلمات
γ	ثابت نعومة التدرّج
λ	قوّة التنظيم (التحدّب القوي)
$\alpha_t,\ T$	معدّل الخطوة وعدد الخطوات
$b,\ q$	حجم الدفعة ومعدّل أخذ العيّنات
$\tau,\ m$	زمن الخلط ونافذة التوسيط
μ	ثابت التقلّص أو الزخم (بحسب السياق)
$\varepsilon,\ \delta_{\text{DP}}$	ميزانية الخصوصية التفاضلية
$C,\ \sigma$	سقف القصّ ومعلَم الضجيج
$\widehat{R}_{\text{LOO}}$	مقدّر «اترك واحداً خارجاً»
$\mathfrak{R}_n,\ d$	متوسط Rademacher وبُعد VC
p	عدد معلمات الشبكة

مراجع

- Bousquet & Elisseeff — «Stability and Generalization»، *Journal of Machine Learning Research* 2 (2002): التأسيس الحديث لحدود الاستقرار الموحّد.
- Hardt, Recht & Singer — «Train faster, generalize better: Stability of stochastic gradient descent»، *ICML* 2016 (ونسخة *JMLR*): حدود استقرار هبوط التدرّج العشوائي.
- Shalev-Shwartz & Ben-David — *Understanding Machine Learning*: الإطار العام، والاستقرار، والصلات بـ ERM و SRM.
- Shalev-Shwartz, Shamir, Srebro & Sridharan — «Learnability, Uniform Convergence and Stability»: حدود التبادل بين المنهجيتين.

• Roth & Dwork — «Algorithmic Foundations of Differential Privacy»: الخصوصية التفاضلية وتركيبها.

• Roth & Reingold — «Reusable Holdout: Preserving Validity in Adaptive Data Analysis»، *Science* 2015: الخصوصية ⇒ التعميم.

• Abadi وآخرون — «Deep Learning with Differential Privacy»، *CCS* 2016: DP-SGD ومحاسبة العزوم.

• Vinyals & Recht — «Understanding Deep Learning Requires Rethinking Generalization» (*ICLR* 2017، ونسخة *JMLR* 2021): تجارب التسميات العشوائيّة.

• Kolter & Nagarajan — «On the inability of gradient descent to explain convergence in deep learning»، *NeurIPS* 2019: الحدود المحسوبة على شبكات حقيقية.

• Mehrabian & Liaw — «Nearly-tight VC-dimension bounds for piecewise-linear neural networks»، *COLT* 2019: بُعد VC لشبكات ReLU.

• Wagner & Devroye — «Distribution-free consistency results in nonparametric discrimination and regression estimation»: استقرار أقرب الجيران.

• Kohavi — «A study of cross-validation and bootstrap for accuracy estimation and model selection»: اختيار عدد الأضعاف.

• McDiarmid — «Concentration via Bounded Differences»: المتراجحة التي بُني عليها كلّ هذا الفصل (الفصل 17).

• Polyak & Juditsky — «Acceleration of Stochastic Approximation by Averaging»: توسيط المتكرّرات.

خاتمة: أعطانا هذا الفصل جواباً على السؤال الذي عجزت عنه حدود السعة: **كيف تبحث** في فضاء الفرضيات لا كم اتّسع. الاستقرار وحدة قياس واحدة تفسّر التنظيم، والتوقّف المبكر، والتجميع، والتحقق المتقاطع، والخصوصية التفاضلية. لكنّه يترك سؤالين مفتوحين: لماذا يعمّم نموذج استوعب بياناته بالكامل؟ ولماذا يهبط الخطأ ثانيةً بعد عتبة الاستيعاب؟ الإجابة تحتاج تحليلاً أدقّ لانحياز المُحسِّن الضمني ودور الهامش في الأبعاد العالية، وهو موضوع **الفصل الرابع والثلاثين — حدود التعميم في الشبكات العميقة.**

حدود التعميم في الشبكات العميقة

«إذا كانت النظرية تصرخ بأنّ الشبكة يجب أن تفشل، وكانت الشبكة تنجح، فالنظرية هي التي تحتاج إلى مراجعة — لا التجربة.»

بنينا في الفصول 30–33 آلةً كاملة لضبط التعميم: إطار الخطر والخطر التجريبي و (ERM) و (SRM) في الفصل 30، وبُعد VC وتعقيد Rademacher في الفصل 31، ونظرية (PAC) والضمانات الإحصائية في الفصل 32، والاستقرار الخوارزمي في الفصل 33. كلّها تُنتج حدّاً على شكلٍ واحد: خطر تجريبي زائد عقوبة سعة. وتلك الآلة تعمل جيّداً ما دام فضاء الفرضيات «أصغر» من العيّنة.

ثمّ جاءت الشبكات العميقة الحديثة فكسرت الافتراض من جذوره: شبكة بعشرات الملايين من المعلمات تُدرَّب على خمسين ألف صورة، تُصفّر خطأ التدريب، **ومع ذلك** تعمّم تعميماً جيّداً على بيانات لم ترها. بل الأسوأ: الشبكة نفسها تُصفّر خطأ التدريب حتى لو استبدلنا الوسوم بوسوم عشوائية — أي أنّ سعتها تكفي لحفظ الضجيج. وحين نُدخل أرقام هذه الشبكة في حدود الفصلين 31 و32 نحصل على حدود **فارغة** :(vacuous) رقم أكبر من 1، أي أكبر من أقصى خطر ممكن، أي بلا أيّ معنى.

هذا الفصل هو محاكمة النظرية أمام الواقع، وإعادة بنائها: كيف نفسّر تعميم شبكة تستطيع حفظ العيّنة؟ وما الحدود التي تبقى غير فارغة حين تُحسب بالأرقام؟

سبع نظريات:

- **2.34 مفارقة المعلمات الزائدة** — لماذا تصير حدود الفصلين 31 و32 فارغة، ولماذا الحفظ ليس تعلّماً؟
- **3.34 حدود معيارية (norm-based) / (margin)** — تعميم يضبطه المعيار الطيفي والهامش لا عدد المعلمات.
- **4.34 حدود (PAC-Bayes)** — أوّل عائلة حدود تعطي أرقاماً غير فارغة على شبكات حقيقية.
- **5.34 حدود الضغط (compression)** — إن استطعت وصف الشبكة بـ k معلمات، فالحدّ يتحدّد بـ k لا بـ p.
- **6.34 الانحياز الضمني للمُحسِّن** — لماذا يختار (SGD) حلولاً تعمّم، ولماذا يختلف عن ؟(Adam)
- **7.34 الهبوط المزدوج والاستيعاب الحميد** — لماذا يهبط الخطر مرّتين، ومتى يكون الاستيعاب نعمة ومتى نقمة؟
- **8.34 نواة التماس العصبية (NTK)** — حين يتّسع العرض تصير الشبكة انحداراً بنواة ثابتة: ماذا نربح وماذا نخسر؟

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
n	حجم عيّنة التدريب	5×10^4 نموذجياً في الرؤية
p (أو W)	عدد معلمات الشبكة	10^7 فأكثر
L	عدد الطبقات (العمق)	يظهر في الحدود بصيغة $L^{3/2}$
W_l	مصفوفة أوزان الطبقة l	
$\|W_l\|_\sigma$	المعيار الطيفي (أكبر قيمة مفردة)	يقيس «التضخيم» الطبقي
$\|W_l\|_{2,1}$	معيار $\ell_{2,1}$ (مجموع معايير الأعمدة)	يظهر في صيغة بارتليت الكاملة
X	مصفوفة المُدخلات $n \times d_0$	
$\|X\|_F$	معيار فروبنيوس لـ X	$= \sqrt{n}$ إن كانت صفوفه معياريّة
γ	الهامش (margin) على المُخرَج	يقاس قبل الدالّة الفاصلة
m	عرض الطبقة المخفية	نظام العرض اللانهائي: $m \to \infty$
$P,\ Q$	التوزيع القبلي والبعدي في (PAC-Bayes)	Q يُتعلَّم بعد رؤية البيانات
$\mathrm{KL}(Q\|P)$	تباعد (KL) بين التوزيعين	«سعة» التوزيع البعدي
$\mathrm{kl}(q\|p)$	تباعد (KL) بين برنوليّتين	صيغة ماورر المضبوطة
k	عدد معلمات الوصف المضغوط	$k \ll p$ بعد التقليم/التكميم
b	عدد البتّات لكلّ معلمة	$b = 32$ عادةً، و 4 بعد التكميم
Θ	نواة التماس العصبية (NTK)	على العيّنة $n \times n$
$\lambda_i(\Sigma)$	طيف مصفوفة التغاير/النواة	
$r_k,\ R_k$	الرتبة الفعّالة للطيف	شرط الاستيعاب الحميد
$\Pi_{\mathcal{H}}(m)$	دالّة النموّ	2^m إن كان $m \le d_{VC}$
$\hat{\mathfrak{R}}_n$	تعقيد Rademacher التجريبي	محصور بـ $\frac{1}{2}$ لخسارة في $[0,1]$
$\eta,\ t$	حجم الخطوة وعدد الخطوات	نظام التدريب الكسول

اتفاقيات هذا الفصل: الخسارة محصورة في $[0,1]$ في كلّ الحدود (لضمان صلاحية متراجحات التركيز من الفصل 17). الحدود كلّها باحتمال $\ge 1-\delta$ على سحب العيّنة، و $\delta = 0.05$ قيمة مرجعية في كلّ الأمثلة ما لم يُذكر خلاف ذلك. ونكتب $\tilde{O}$ للتعبير عن رتبة تحذف الثوابت المطلقة والعوامل اللوغاريتمية وأسسها؛ وكلّ حساب رقمي في الأمثلة يستخدم الصيغة **بعد** حذف هذه الثوابت، أي أنّه تمرين على بنية الحدّ لا على قيمته النهائية المطلقة.

المبرهنة (مفارقة المعلمات الزائدة): لتكن شبكةٌ عميقة بعدد معلمات p تُدرَّب حتّى الاستيعاب على عيّنة S حجمها n بوسوم في فضاء $\mathcal{Y}$. عندئذٍ:

أوّلاً — الحفظ ممكن عدديّاً: تكفي ميزانية بتّات $p\,b$ لتمثيل 2^{pb} حالةً مختلفة؛ لأنّ حفظ n وسماً يحتاج $n \log_2 |\mathcal{Y}|$ بتّاً، فإنّ

$$p\,b \;\ge\; n \log_2 |\mathcal{Y}| \qquad \Longrightarrow \qquad \text{يوجد اختيار للمعلمات يحقّق } \hat{R}_S(h) = 0 \tag{1.34}$$

حتّى على وسوم عشوائية.

ثانياً — حدّ نموّ النموّ يصير فارغاً: بحدّ الفصل 31 الموحّد،

$$R(\hat{h}) \;\le\; \hat{R}_S(\hat{h}) \;+\; \underbrace{\sqrt{\frac{8}{n}\ln\frac{4\,\Pi_{\mathcal{H}}(2n)}{\delta}}}_{\Omega_{VC}} \tag{2.34}$$

فإذا كان $d_{VC} \ge 2n$ — وهو الحال دائماً في الشبكات العميقة حيث $d_{VC} = \Omega(WL)$ و $W \gg n$ — فإنّ $\Pi_{\mathcal{H}}(2n) = 2^{2n}$، وبالتالي

$$\Omega_{VC} \;=\; \sqrt{16\ln 2 \;+\; \frac{8}{n}\ln\frac{4}{\delta}} \;\approx\; 3.33 \;>\; 1 \tag{3.34}$$

ثالثاً — حدّ Rademacher يصير فارغاً: وبحدّ الفصل 31 الثاني،

$$R(\hat{h}) \;\le\; \hat{R}_S(\hat{h}) \;+\; 2\,\hat{\mathfrak{R}}_n(\ell \circ \mathcal{H}) \;+\; 3\sqrt{\frac{\ln(2/\delta)}{2n}} \;\ge\; 1 \tag{4.34}$$

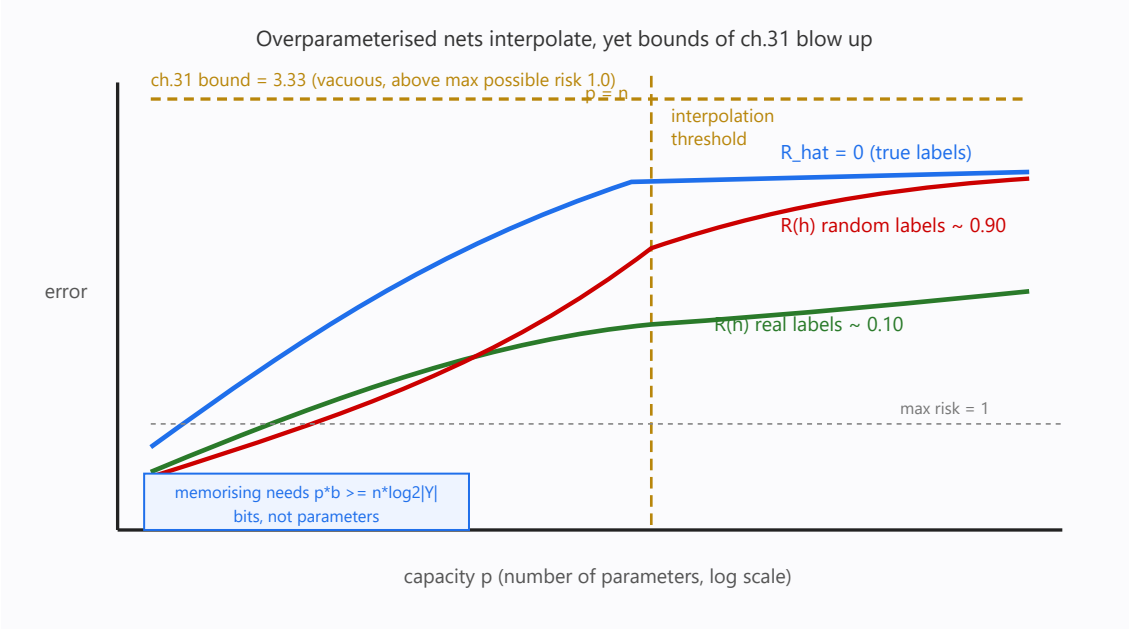
لأنّ تعقيد Rademacher لصنف قادر على ملاءمة أيّ وسوم يبلغ أقصاه $\hat{\mathfrak{R}}_n = \frac{1}{2}$، فتصير الإضافة وحدها ≥ 1. أي أنّ الحدّين (2.34) و (4.34) **فارغان**: لا يقولان شيئاً عن الشبكة مهما كانت جيّدة.

جدول الرموز

الرمز	المعنى	ملاحظة
$p\,b$	ميزانية البتّات	قدرة تخزين نظريّة
$n \log_2 \lVert\mathcal{Y}\rVert$	بتّات لازمة لحفظ الوسوم	بتّاً $n \Rightarrow \lvert\mathcal{Y}\rvert = 2$
$\hat{R}_S(\hat{h}) = 0$	استيعاب	interpolation
$d_{VC} = \Omega(WL)$	بُعد VC لشبكة (ReLU)	ينمو مع الوزن والعمق
$\Pi_{\mathcal{H}}(m)$	دالّة النموّ	إن $m \le d$ فـ 2^m، و $\sum_{i=0}^{d}\binom{m}{i}$ =
$2n$	حجم «العيّنة الشبح»	يظهر في حدّ نموّ النموّ
$\hat{\mathfrak{R}}_n$	تعقيد Rademacher	أقصاه $\frac{1}{2}$ لخسارة في $[0,1]$
فارغ (vacuous)	الحدّ $\ge$ أقصى خطر ممكن	أي ≥ 1

الرسم

<figure> الشكل<figcaption> 1.34: تتجاوز سعة الشبكة نقطة الاستيعاب، فيصفّر خطأ التدريب على الوسوم الحقيقية



شكل ١.٣٤: *
مفارقة المعلمات الزائدة وفجوة التعميم

والوسوم العشوائية معاً، بينما يبقى خطر الاختبار صغيراً في الحالة الأولى فقط، وتنفجر حدود الفصلين 31 و32 في الحالتين.</figcaption> </figure>

البرهان

الخطوة 1 (قدرة الحفظ — عدّ البتّات): كلّ معلمة بـ b بتّاً تعطي 2^b حالة، و p معلمات تعطي 2^{pb} اختياراً مختلفاً. ولتخزين وسومٍ عشوائية لـ n نقطة في فضاء من $|\mathcal{Y}|$ فئة نحتاج تمييز $|\mathcal{Y}|^n$ حالة، أي $n\log_2|\mathcal{Y}|$ بتّاً. فإذا كان $pb \geq n\log_2|\mathcal{Y}|$ وُجدت معلمات تمثّل الوسوم، أي أنّ حفظ الضجيج ليس مفارقة بل حساب بتّات. ■ (لاحظ أنّ هذا حدّ وجودي: لا يقول إنّ (SGD) سيجد الحلّ، بل إنّ الحلّ موجود؛ وهذا أحد أسباب وفرة المعلمات: التسهيل على المُحسِّن.)

الخطوة 2 (نموّ النموّ ينفجر): بخاصية ساور–شيلاه، $\Pi_{\mathcal{H}}(m) = \sum_{i=0}^{d_{VC}} \binom{m}{i}$، وإذا كان $m \leq d_{VC}$ فإنّ المجموع يساوي 2^m تماماً. وفي شبكة (ReLU) بـ W وزناً و L طبقة، البعد من رتبة $\Omega(WL)$، فمع $W = 10^7$ و $L = 16$ نحصل على d_{VC} من رتبة 1.6×10^8، وهو أكبر من $2n$ لكلّ n معقول. إذن $\Pi_{\mathcal{H}}(2n) = 2^{2n}$. ■

الخطوة 3 (استنتاج الفَراغ): نعوّض في (2.34):

$$\Omega_{VC} = \sqrt{\frac{8}{n}\Big(\ln\frac{4}{\delta} + 2n\ln 2\Big)} = \sqrt{16\ln 2 + \frac{8}{n}\ln\frac{4}{\delta}}$$

والحدّ الثاني موجب، فـ $\Omega_{VC} > \sqrt{16\ln 2} = 3.330$. وبما أنّ أيّ خطر محصور في $[0,1]$، فإنّ الحدّ لا يحمل معلومة. ■ لاحظ أيضاً أنّ الحدّ **لا يتحسّن بزيادة** n ما دام $d_{VC} \geq 2n$: لأنّ المقدار المهيمن $16\ln 2$ مستقلّ عن n.

الخطوة 4 (Rademacher لا ينقذنا): بتعريفه $\hat{\mathfrak{R}}_n(\mathcal{F}) = \mathbb{E}_\sigma\big[\sup_{f\in\mathcal{F}} \frac{1}{n}\sum_i \sigma_i f_i\big]$؛ فإذا كان الصنف قادراً على اتّخاذ أيّ قيم في $[0,1]$ على العيّنة — وهو ما يحدث عند ملاءمة وسوم عشوائية — فإنّ الاختيار $f_i = 1$ حيث $\sigma_i = +1$ و $f_i = 0$ حيث $\sigma_i = -1$ يعطي $\frac{1}{n}\#\{i : \sigma_i = +1\}$ متوقّعه $\frac{1}{2}$. فـ $2\hat{\mathfrak{R}}_n = 1$ والحدّ (4.34) ≥ 1. ■

الخطوة 5 (المفارقة نفسها): التجربة Zhang) وآخرون، 2017) على :(CIFAR-10) استبدال الوسوم بوسوم عشوائية يعطي خطأ تدريب 0 وخطأ اختبار $0.90 \approx$ (= مستوى الصدفة في 10 فئات)، بينما الوسوم الحقيقية تعطي خطأ تدريب 0 وخطأ اختبار $0.10 \approx$. الفضاء واحد في الحالتين، والسعة واحدة، فلا يمكن لحدٍّ يعتمد على $\mathcal{H}$ وحده أن يفرّق بينهما. هذا هو الدافع الكامل لنظريات 3.34–8.34. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.34): وسوم عشوائية على مجموعة صور المعطيات: $n = 5 \times 10^4$ صورة، $|\mathcal{Y}| = 10$ فئات، شبكة $p = 1.4 \times 10^6$ معلمة، تدريب حتّى الاستيعاب. المطلوب: خطأ الاختبار المتوقّع بعد استبدال الوسوم بوسوم عشوائية، وحجم الفجوة. الحل: الخطوة 1: خطأ الصدفة في 10 فئات $1 - \frac{1}{10} = 0.90$. الخطوة 2: الوسوم العشوائية لا تحمل إشارة، فأفضل ما يمكن توقّعه هو الصدفة: $R \approx 0.90$. الخطوة 3: الشبكة تحقّق $\hat{R}_S = 0 \Rightarrow$ الفجوة $0.90 - 0 = 0.90$. النتيجة: بلوغ خطأ تدريب صفري لا يعني تعلّماً، الفجوة هنا تساوي مستوى الصدفة كاملاً. الربط بالذكاء الاصطناعي: هذه هي تجربة (Zhang) وآخرون (2017) التي أشعلت البحث في نظريات هذا الفصل.

مثال (2-2.34): ميزانية البتّات — كم معلمة تكفي للحفظ؟ المعطيات: $n = 5 \times 10^4$ وسماً ثنائيّاً، أوزان مخزّنة بـ $b = 32$ بتّاً. المطلوب: أقلّ عدد معلمات قادر نظريّاً على حفظ العيّنة. الحل: الخطوة 1: البتّات اللازمة $= n\log_2 2 = n = 5 \times 10^4$. الخطوة 2: البتّات المتاحة $32p \Rightarrow$ نشترط $32p \geq 5 \times 10^4$. الخطوة 3: $p \geq 1562.5 \Rightarrow$ نحو 1563 معلمة تكفي نظريّاً. النتيجة: الحفظ رخيص جدّاً، وفرة المعلمات ليست شرطاً للحفظ بل لتسهيل عمل المُحسِّن. الربط بالذكاء الاصطناعي: يفسّر لماذا تحفظ الشبكات الصغيرة عيّناتها، ولماذا لا يكفي تقليص المعلمات وحده لضمان التعميم.

مثال (3-2.34): حساب حدّ نموّ النموّ على شبكة رؤية المعطيات: $W = 10^7$ وزناً، $L = 16$ طبقة، $n = 5 \times 10^4$، $\delta = 0.05$. المطلوب: قيمة Ω_{VC} في (3.34). الحل: الخطوة 1: $d_{VC} = \Omega(WL) \Rightarrow$ تقدير متحفّظ $d = 1.6 \times 10^8$. الخطوة 2: $\Pi_{\mathcal{H}}(2n) = 2^{10^5} \Rightarrow 2n = 10^5 < d$. الخطوة 3: $\ln \frac{4\Pi}{\delta} = \ln 80 + 10^5 \ln 2 = 69319.1$. الخطوة 4: $\sqrt{11.091} = 3.330$. النتيجة: $\Omega_{VC} = \sqrt{\frac{8}{5\times10^4} \times 69319.1}$. $4.382 + 69314.7 = 69319.1$

الحدّ 3.33 أكبر من أقصى خطر ممكن (=1) $\Rightarrow$ فارغ تماماً. الربط بالذكاء الاصطناعي: لا جدوى من «جمع مزيد من البيانات» لإصلاح هذا الحدّ (المثال التالي).

مثال (4-2.34): زيادة البيانات لا تنقذ الحدّ الفارغ المعطيات: المسألة نفسها مع $n = 10^6$ (عيّنة أكبر بعشرين ضعفاً)، $\delta = 0.05$. المطلوب: هل يتحسّن الحدّ؟ الحل: الخطوة 1: ما زال $d = 1.6 \times 10^8 > 2n = 2 \times 10^6$. الخطوة 2: $\Pi = 2^{2n} \Rightarrow \Omega_{VC} = \sqrt{16 \ln 2 + \frac{8}{10^6} \ln 80} = \sqrt{11.0904 + 0.0000351}$. الخطوة 3: $\Omega_{VC} = 3.3302$. النتيجة: الحدّ ثابت تقريباً ($3.330 \to 3.330$): لأنّ المقدار المهيمن $16 \ln 2$ لا يعتمد على n. الربط بالذكاء الاصطناعي: حدود تعتمد على السعة وحدها لا تتحسّن بالبيانات إن كانت السعة لانهائيّة عمليّاً.

مثال (5-2.34): حدّ Rademacher على وسوم عشوائية المعطيات: خسارة محصورة في $[0,1]$، $\hat{\mathfrak{R}}_n = \frac{1}{2}$ (الأقصى)، $\hat{R}_S = 0$، $n = 5 \times 10^4$، $\delta = 0.05$. المطلوب: قيمة الحدّ في (4.34). الحل: الخطوة 1: $\ln(2/\delta) = \ln 40 = 3.6889$. الخطوة 2: الحدّ الثالث $= 3 \times 0.006074 = 0.01822$. الخطوة 3: الحدّ $1.01822 = 0.01822 + 0.5 \times 2 + 0 =$. النتيجة: الحدّ يتجاوز 1 $\Rightarrow$ فارغ. الربط بالذكاء الاصطناعي: تعقيد Rademacher يقيس «قابلية ملاءمة الضجيج» بالضبط، ولذلك ينفجر عند الوسوم العشوائية — وهذا هو المعنى الإيجابي له.

مثال (6-2.34): نسبة المعلمات إلى البيانات في التصوير الطبي المعطيات: شبكة أشعة بـ $p = 2.5 \times 10^7$ و $L = 24$ طبقة، $n = 2000$ صورة موسومة. المطلوب: نسبة السعة إلى العيّنة، وقيمة الحدّ. الحل: الخطوة 1: $p/n = 2.5 \times 10^7 / 2000 = 12500$. الخطوة 2: $2n = 4000$. $\Pi = 2^{2n} \Rightarrow d \approx pL = 6 \times 10^8 \gg 2n$. الخطوة 3: $\Omega_{VC} = \sqrt{16 \ln 2 + \frac{8}{2000} \times 4.382} = \sqrt{11.0904 + 0.01753} = \sqrt{11.1079} = 3.3330$. النتيجة: الحدّ 333.3 مع أنّ خطأ الاختبار المقاس قد يكون 0.08 فقط. الربط بالذكاء الاصطناعي: في المجالات الطبية تكون n صغيرة والسعة هائلة، فالفجوة بين النظرية والواقع في أقصاها.

مثال (7-2.34): نموذج لغوي كبير — الحدّ فارغ رغم أنّ المعلمات أقلّ من الرموز المعطيات: نموذج بـ $W = 7 \times 10^9$ معلمة و $L = 32$ طبقة، $n = 2 \times 10^{12}$ رمزاً تدريبيّاً، $\delta = 0.05$. المطلوب: هل يصير الحدّ غير فارغ لأنّ $W < n$؟ الحل: الخطوة 1: $d \approx WL = 2.24 \times 10^{11}$، و $2n = 4 \times 10^{12} > d \Rightarrow$ نستخدم صيغة $d \ln \frac{2en}{d}$. الخطوة 2: $\frac{2en}{d} = \frac{5.4366 \times 2 \times 10^{12}}{2.24 \times 10^{11}} = 48.54$ ولوغاريتمه 3.8825. الخطوة 3: $\ln \Pi = d \times 3.8825 = 8.697 \times 10^{11}$. الخطوة 4: $\Omega_{VC} = \sqrt{\frac{8}{2\times10^{12}}(8.697 \times 10^{11} + 4.382)} = \sqrt{3.4788} = 1.865 \Rightarrow 1.865 > 1$. النتيجة: الحدّ ما زال فارغاً، رغم أنّ عدد المعلمات أقلّ من عدد الأمثلة بـ 285 ضعفاً. الربط بالذكاء الاصطناعي: الحدّ يقيس الأسّ في السعة (عدد التصرّفات الممكنة) لا عدد المعلمات، والنماذج الكبيرة تعمل خارج نطاق هذه الحدود.

مثال (8-2.34): فجوة التعميم المقاسة مقابل الحدّ — تشخيص المعطيات: خطأ تدريب 0.01، خطأ اختبار 0.09، والحدّ من (3.34) $= 3.330$. المطلوب: نسبة التضخّم في الحدّ. الحل: الخطوة 1: الفجوة الحقيقية $0.09 - 0.01 = 0.08$. الخطوة 2: النسبة $= 3.330/0.08 = 41.6$. النتيجة: الحدّ يضخّم الفجوة الحقيقية بنحو 42 ضعفاً، هو صحيح لكنّه غير معلّم. الربط بالذكاء الاصطناعي: الحدّ الصحيح غير المعلّم لا يصلح لاتّخاذ قرار هندسي (هل أزيد تنظيماً؟).

مثال (9-2.34): كشف الاحتيال المالي المعطيات: $n = 10^4$ عملية، شبكة $p = 5 \times 10^5$ معلمة، $\delta = 0.05$.

المطلوب: الحدّ، ومقارنته بالفجوة المقاسة 0.12. الحل: الخطوة 1: $d \approx pL = 5 \times 10^5 \times 6 = 3 \times 10^6 \gg 2n =$ $\Pi = 2^{2n} \Rightarrow 2 \times 10^4$. الخطوة 2: $\Omega_{VC} = \sqrt{16 \ln 2 + \frac{8}{10^4} \ln 80} = \sqrt{11.0904 + 0.03506} = 3.3359$. الخطوة 3: النسبة إلى الفجوة المقاسة $3.3359/0.12 = 27.8$. النتيجة: الحدّ لا يفيد في تحجيم المخاطر المالية، ولذلك يُعتمد في القطاع على التحقّق الزمني الصارم. الربط بالذكاء الاصطناعي: في المالية تكون i.i.d. نفسها موضع شكّ (الفصل 30)، فالحدّ مزدوج الضعف.

مثال (10-2.34): تعلّم السياسات في الروبوتات المعطيات: $n = 500$ مسار، شبكة سياسة $p = 10^6$ معلمة، $\delta = 0.05$. المطلوب: قيمة الحدّ. الحل: الخطوة 1: $\Pi = 2^{1000} \Rightarrow d \approx 10^6 \times 4 = 4 \times 10^6 \gg 2n = 1000$. الخطوة 2: $\Omega_{VC} = \sqrt{16 \ln 2 + \frac{8}{500} \times 4.382} = \sqrt{11.0904 + 0.07011} = \sqrt{11.1605} = 3.3407$. النتيجة: الحدّ 341.3، والواقع أنّ السياسات تُقيَّم بالتجربة المباشرة لا بالحدود. الربط بالذكاء الاصطناعي: في التعلّم المعزّز البيانات ليست i.i.d. أصلاً، فالنظرية الإحصائية هنا إرشادية فقط.

مثال (11-2.34): كشف التسلّل على نطاق واسع المعطيات: $n = 10^6$ حدث، شبكة $p = 10^8$ معلمة، الفجوة المقاسة 0.03، $\delta = 0.05$. المطلوب: الحدّ ونسبة التضخّم. الحل: الخطوة 1: $\Omega_{VC} = \sqrt{16 \ln 2 + \frac{8}{10^6} \times 4.382} =$ 3.3302. الخطوة 2: النسبة $3.3302/0.03 = 111.0$. النتيجة: مع بيانات ضخمة تبقى النسبة فادحة لأنّ الحدّ لا يتقلّص مع n. الربط بالذكاء الاصطناعي: الأمن السيبراني يعتمد على قياس مباشر لمعدّل الكشف الخاطئ بدل الحدود النظرية.

مثال (12-2.34): تصنيف المشاعر بلغة عربية المعطيات: $n = 2.5 \times 10^4$ نصّ، نموذج $p = 1.1 \times 10^8$ معلمة (نموذج لغوي مضبوط)، $\delta = 0.05$. المطلوب: قيمة الحدّ. الحل: الخطوة 1: $\Pi = \Rightarrow d \approx pL \gg 2n$ $= 2^{5 \times 10^4}$. الخطوة 2: $\Omega_{VC} = \sqrt{16 \ln 2 + \frac{8}{2.5 \times 10^4} \times 4.382} = \sqrt{11.0904 + 0.001402} = 3.3304$. النتيجة: الحدّ 330.3 مع دقّة اختبار مقاسة قد تبلغ 92.0. الربط بالذكاء الاصطناعي: الضبط الدقيق للنماذج الكبيرة على عيّنات صغيرة هو الحالة التي تعجز فيها هذه الحدود تماماً.

مثال (13-2.34): ما أكبر سعة يستطيع الحدّ احتمالها؟ المعطيات: $n = 5 \times 10^4$، $\delta = 0.05$، ونشترط أن يكون الحدّ غير فارغ بمعنى $\Omega_{VC} \le 0.5$. المطلوب: أكبر d_{VC} مسموح. الحل: الخطوة 1: $\Rightarrow \frac{8}{n}\left(d \ln \frac{2en}{d} + \ln \frac{4}{\delta}\right) \le 0.25$ $d \ln \frac{2en}{d} \le \frac{0.25n}{8} - 4.382 = 1562.5 - 4.382 = 1558.1$. الخطوة 2: نجرّب $d = 218$: $\frac{2en}{d} = 1246.9$، $\ln = 7.1283$، الناتج $1554.0 \le 1558.1$ ✓. الخطوة 3: نجرّب $d = 220$: $\frac{2en}{d} = 1235.6$، $\ln = 7.1196$، الناتج $1566.3 > 1558.1$ ×. النتيجة: السعة الفعّالة يجب أن تكون $d \lesssim 219$ بُعداً — أي نحو 0.44% من حجم العيّنة — ليكون الحدّ ذا معنى. الربط بالذكاء الاصطناعي: أيّ شبكة حقيقية تتجاوز هذه السعة بآلاف الأضعاف، ولذلك الانتقال إلى حدود 3.34–8.34 ضروري لا تحسيني.

مثال (14-2.34): سعة حفظ النماذج اللغوية الكبيرة المعطيات: نموذج بـ $p = 7 \times 10^9$ معلمة مخزّنة بـ $b = 16$ بتّاً، وترميز النصّ بنحو 4 بتّات للرمز. المطلوب: كم رمزاً يستطيع النموذج حفظه نظريّاً؟ الحل: الخطوة 1: الميزانية $pb = 7 \times 10^9 \times 16 = 1.12 \times 10^{11}$ بتّاً. الخطوة 2: عدد الرموز $\frac{1.12 \times 10^{11}}{4} = 2.8 \times 10^{10}$ رمزاً. النتيجة: عشرات المليارات من الرموز قابلة للحفظ نظريّاً ⇐ خطر التسرّب والحفظ خطرٌ كمّي لا نظري. الربط بالذكاء الاصطناعي: يبرّر ممارسات قياس «التسرّب» وتقييم الحفظ في النماذج الكبيرة.

مثال (15-2.34): كيف نقرأ حدّاً فارغاً؟ المعطيات: حدّ $= 3.330$، فجوة مقاسة $= 0.10$، في مسألة رؤية. المطلوب: هل نرفض النظرية؟ الحل: الخطوة 1: الحدّ صحيح منطقيّاً: لم يُنتهك؛ هو فقط لا يفرّق بين احتمالات واسعة. الخطوة 2: مصدر الضعف بنيوي: الحدّ يعتمد على $\mathcal{H}$ و n فقط، ولا يعتمد على الخوارزمية ولا على التوزيع $\mathcal{D}$. الخطوة

3: العلاج: إدخال الخوارزمية والتوزيع في الحدّ — وهو ما تفعله 3.34 (المعايير)، 4.34 (التوزيع البعدي)، 5.34 (الضغط)، 6.34 (المُحسِّن)، 8.34 (النواة). النتيجة: الحدّ الفارغ ليس خطأً في الحساب بل علامة على أنّ السؤال طُرح بالمقياس الخطأ. الربط بالذكاء الاصطناعي: هذه هي خريطة هذا الفصل: استبدال «سعة الفضاء» بـ«سعة الحلّ المحقَّق».

أخطاء شائعة

- الظنّ أنّ خطأ تدريب صفري يعني فشل التعميم حتماً (الاستيعاب قد يكون حميداً، النظرية 7.34).
- الظنّ أنّ الحدّ الفارغ يعني أنّ النظرية خاطئة (هو صحيح لكن غير معلّم).
- استخدام عدد المعلمات p مقياساً للسعة (الصحيح: المعايير والهامش، النظرية 3.34).
- توقّع تحسّن حدود بُعد VC بجمع البيانات (لا تتحسّن ما دام $d_{VC} \geq 2n$).
- تجربة «الوسوم العشوائية» ثمّ الاستنتاج أنّ الشبكة لا تتعلّم شيئاً (الحفظ قدرة، والتعميم اختيارٌ للمُحسِّن).
- خلط «يوجد حلّ يحفظ» مع (SGD)» يجد حلّاً يحفظ»: الأوّل وجودي والثاني خوارزمي.

المبرهنة (بارتليت، فوستر، وتيلغارسكي 2017 — صيغة مبسّطة): لتكن شبكةٌ أمامية بـ L طبقات وأوزان $W_1, \dots, W_L$ ومُخرَج $f(x)$، ولتكن $h(x) = \arg\max_j f(x)_j$. نعرّف هامش النقطة i بـ

$$m_i \;=\; f(x_i)_{y_i} - \max_{j \neq y_i} f(x_i)_j, \qquad \hat{R}_\gamma(h) \;=\; \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}\big[m_i < \gamma\big] \tag{5.34}$$

فباحتمال $\geq 1-\delta$ على سحب العيّنة، ولكلّ هامش $\gamma > 0$:

$$R(h) \;\leq\; \hat{R}_\gamma(h) \;+\; \tilde{O}\!\left(\frac{\|X\|_F \prod_{l=1}^{L} \|W_l\|_\sigma}{\gamma \sqrt{n}} \, L^{3/2} \right) \tag{6.34}$$

والصيغة الأكمل التي حُذفت منها الثوابت واللوغاريتمات هي

$$R(h) \;\leq\; \hat{R}_\gamma(h) \;+\; \tilde{O}\!\left(\frac{\|X\|_F \, \ln(d_0)}{\gamma \sqrt{n}} \Big(\prod_{l=1}^{L} \|W_l\|_\sigma \Big) \Big(\sum_{l=1}^{L} \frac{\|W_l\|_{2,1}^{2/3}}{\|W_l\|_\sigma^{2/3}} \Big)^{3/2} \right) \tag{7.34}$$

وإذا كانت مُدخلات العيّنة معياريّة ($\|x_i\|_2 = 1$) فإنّ $\|X\|_F = \sqrt{n}$، فيختزل الحدّ إلى صيغةٍ بالغة الدلالة:

$$R(h) \;\leq\; \hat{R}_\gamma(h) \;+\; \tilde{O}\!\left(\frac{L^{3/2}}{\gamma} \, \prod_{l=1}^{L} \|W_l\|_\sigma \right) \tag{8.34}$$

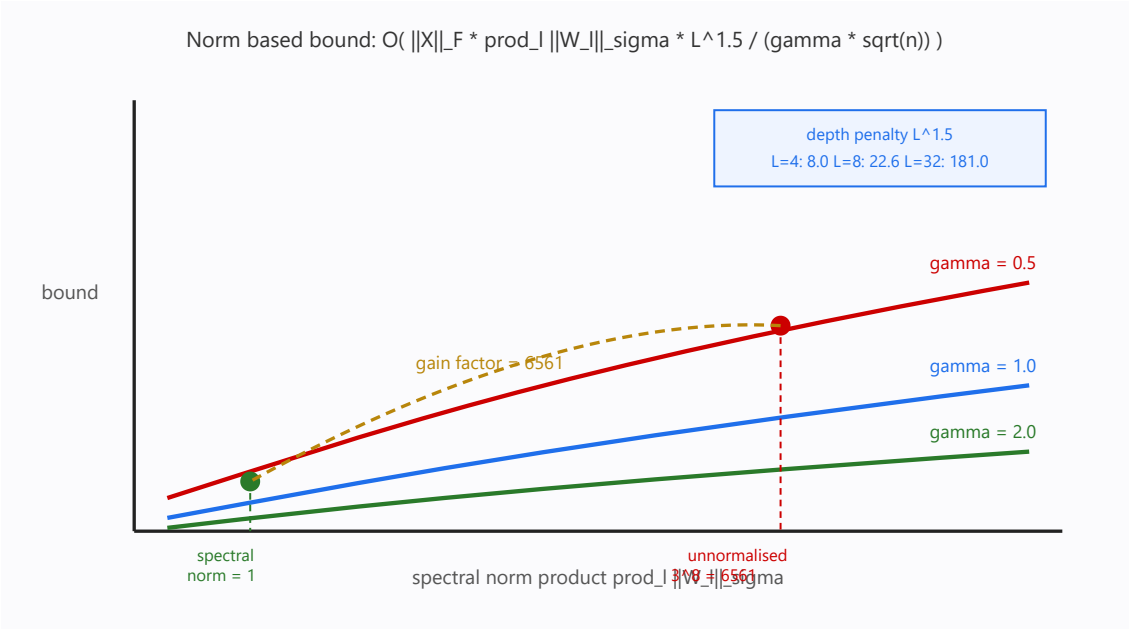
القراءة: الحدّ لا يعتمد على عدد المعلمات p صراحةً؛ يعتمد على حاصل ضرب المعايير الطيفية وعلى الهامش وعلى العمق. فزيادة العرض مع بقاء المعيار الطيفي ثابتاً لا تكلّف شيئاً في الحدّ — بخلاف بُعد VC الذي ينفجر.

جدول الرموز

الرمز	المعنى	ملاحظة
m_i	هامش النقطة i	الفرق بين مُخرَج الفئة الصحيحة وأقوى مُخرَج منافس
$\hat{R}_\gamma$	خطر التصنيف بهامش γ	يرتفع كلّما شدّدنا γ
$\|W_l\|_\sigma$	المعيار الطيفي (أكبر قيمة مفردة)	يقيس تضخيم الطبقة
$\|W_l\|_{2,1}$	مجموع معايير ℓ_2 للأعمدة	يقيس «حجم» الطبقة كلّها
$\|X\|_F$	معيار فروبنيوس للمدخلات	بعد تطبيع الصفوف $= \sqrt{n}$
$L^{3/2}$	عقوبة العمق	التراكم الطبقي للاضطراب
$1/\gamma$	عقوبة ضيق الهامش	الهامش الكبير $\Rightarrow$ حدّ أصغر
$\tilde{O}$	رتبة بلا ثوابت ولا لوغاريتمات	الحدود الرقمية أدناه تقديريّة

الرسم

<figure> الشكل<figcaption> 2.34: يتناقص الحدّ المعياري رتيباً مع هامش أكبر ومعايير طيفية أصغر: التطبيع



شكل ٣٤.٢: *
الحد المعياري بدلالة حاصل ضرب المعايير الطيفية والهامش

الطيفي والتنظيم يفيدان لأنّهما يصغّران هذا الحاصل، لا لأنّهما يقلّلان عدد المعلمات.<figcaption/> </figure>

البرهان

الخطوة 1 (الهامش يخفي السعة): بدل تقييم خطأ 0-1 الخام، نقيّم $\hat{R}_\gamma$: نسبة النقاط التي تُصنَّف بهامش أقلّ من γ. الخطر الحقيقي محصور بـ $R(h) \leq R_\gamma(h)$ لأنّ النقطة المصنّفة بهامش موجب صحيحاً هي نقطة مصنّفة صحيحاً. إذن يكفي ضبط فجوة التعميم لدالّة الهامش.

الخطوة 2 (تحليل الاضطراب): الفكرة: نضيف ضجيجاً صغيراً إلى أوزان كلّ طبقة ونقيس أثره على المُخرَج. بتفاضل الشبكة، اضطراب مقداره Δ_l في الطبقة l يُضخَّم بعامل $\prod_{l' \neq l} \|W_{l'}\|_\sigma$؛ وبجمع الاضطرابات على الطبقات يظهر المقدار $\left(\prod_l \|W_l\|_\sigma\right)\left(\sum_l \|W_l\|_{2,1}^{2/3} / \|W_l\|_\sigma^{2/3}\right)^{3/2}$، وهو «المعيار الفعّال» للشبكة. ■

الخطوة 3 (من الاضطراب إلى تعقيد Rademacher): بتقنية تغطية (covering) على كرة المعلمات المضطربة،

يُحصر تعقيد Rademacher لصنف الشبكات التي معيارها الفعّال B $\leq$ بـ $\tilde{O}\left(\frac{\|X\|_F B}{\sqrt{n}}\right)$؛ والتفصيل يعطي عامل $L^{3/2}$ من جمع الاضطرابات على الطبقات وعامل $\ln(d_0)$ من التغطية. ■

الخطوة 4 (التقسيم بالهامش): تُقسَّم الشبكة على الهامش γ: النقاط ذات الهامش γ $\geq$ لا تتأثّر باضطراب صغير، فيُحصر تعقيد الصنف **المقسوم** بـ $\frac{B}{\gamma}$ بدل B، ومن هنا العامل $1/\gamma$ في (6.34). ■

الخطوة 5 (لماذا الاتجاه هو المهم؟): الأرقام الناتجة عن (6.34) تبقى أكبر من 1 في معظم الشبكات الحقيقية (انظر الأمثلة)، لكنّها **رتيبة في الاتجاه الصحيح**: تتدنّى مع التطبيع الطيفي، ومع التنظيم، ومع تطبيع المدخلات، ومع كبر الهامش — وهي بالضبط التدخّلات التي تحسّن التعميم في الممارسة. هذه هي القيمة العلمية للحدّ: أنّه يرشد الممارسة قبل أن يضمن الرقم. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.34): الحساب المرجعي على شبكة رؤية المعطيات: $n = 5 \times 10^4$ صورة معيّرة ($\|x_i\|_2 = 1$)، $L = 8$ طبقات، $\|W_l\|_\sigma = 3$ لكلّ طبقة، $\gamma = 0.5$. المطلوب: قيمة الحدّ الإضافي من (8.34). الحل: الخطوة 1: $\frac{\|X\|_F}{\sqrt{n}} = 1 \Rightarrow$ نصيغ (8.34) تنطبق. الخطوة 2: $\prod_l \|W_l\|_\sigma = 3^8 = 6561$، و $L^{3/2} = 8^{1.5} = 22.627$. الخطوة 3: الحدّ $= 2.97 \times 10^5 = \frac{148458}{0.5} = \frac{22.627 \times 6561}{0.5}$. النتيجة: الحدّ ضخم (فارغ)، لكنّه **محدود ومحسوب** بخلاف حدّ 2.34 الذي لا يعتمد على الحلّ أصلاً. الربط بالذكاء الاصطناعي: هذه هي النقطة المفاهيمية: الحدّ صار دالّةً في الحلّ المُتعلَّم لا في الفضاء وحده.

مثال (2-3.34): أثر التطبيع الطيفي المعطيات: الشبكة نفسها بعد تطبيع طيفي يفرض $\|W_l\|_\sigma = 1$ لكلّ طبقة. المطلوب: الحدّ الجديد ونسبة التحسّن. الحل: الخطوة 1: $\prod_l \|W_l\|_\sigma = 1^8 = 1$. الخطوة 2: الحدّ $= \frac{22.627 \times 1}{0.5} = 45.25$. الخطوة 3: التحسّن $= 6561$ ضعفاً (يساوي حاصل الضرب الأوّل بالضبط). النتيجة: التطبيع الطيفي يقلّص الحدّ بأربعة أوامر من حيث الحجم دون حذف معلمة واحدة. الربط بالذكاء الاصطناعي: يفسّر نجاح التطبيع الطيفي في الشبكات التوليدية التنافسية والتعلّم المقاوِم.

مثال (3-3.34): أثر رفع الهامش المعطيات: الحالة المطبّعة طيفيّاً ($\prod \|W_l\|_\sigma = 1$) مع رفع الهامش من $\gamma = 0.5$ إلى $\gamma = 2$. المطلوب: الحدّ الجديد. الحل: الخطوة 1: الحدّ يتناسب عكسيّاً مع γ. الخطوة 2: γ تضاعف 4 مرّات $\Rightarrow$ الحدّ $= 45.25/4 = 11.31$. النتيجة: تحسين الهامش أرخص من تحسين المعايير هنا (عامل 4 مقابل عامل 6561). الربط بالذكاء الاصطناعي: يبرّر خسائر الهامش الصريحة والتعلّم بهامش كبير في التصنيف.

مثال (4-3.34): أثر العمق المعطيات: $\prod \|W_l\|_\sigma = 1$، $\gamma = 0.5$، ونقلليا العمق من $L = 8$ إلى $L = 4$. المطلوب: الحدّ الجديد. الحل: الخطوة 1: $L^{3/2}$: من $8^{1.5} = 22.627$ إلى $4^{1.5} = 8$. الخطوة 2: الحدّ $= \frac{8}{0.5} = 16.0$. النتيجة: العمق يكلّف بعقوبة $L^{3/2}$: مضاعفة العمق ترفع الحدّ بنحو $2^{1.5} = 2.83$ ضعفاً. الربط بالذكاء الاصطناعي: يبرّر الوصلات المتبقّية: عمقٌ كبير بمعايير طبقية أصغر.

مثال (5-3.34): أثر التنظيم الصريح (weight decay) المعطيات: التنظيم يخفض كلّ معيار طيفي من 3 إلى 1.5 في شبكة $L = 8$، و $\gamma = 0.5$. المطلوب: الحدّ الجديد والتحسّن. الحل: الخطوة 1: $\prod \|W_l\|_\sigma = 1.5^8 = 25.629$. الخطوة 2: الحدّ $= \frac{579.9}{0.5} = 1160 = \frac{22.627 \times 25.629}{0.5}$. الخطوة 3: التحسّن $= 2^8 = 256$ ضعفاً (كلّ طبقة أسهمت بعامل 2). النتيجة: التنظيم يعمل **طبقيّاً بالضرب**: تحسين متواضع في كلّ طبقة يعطي تحسّناً هائلاً في الحدّ. الربط بالذكاء الاصطناعي: يفسّر لماذا يكون للتنظيم أثر أكبر من أثره في تقليص عدد المعلمات.

مثال (6-3.34): أثر تطبيع المدخلات في الرؤية المعطيات: صور خام بمعيار $\|x_i\|_2 = 27.71$ (بكسلات

3×32×32)، $L = 8$، $\prod \|W_l\|_\sigma = 1$، $\gamma = 0.5$. المطلوب: الحدّ قبل تطبيع الصفوف وبعده. الحل: الخطوة 1: $\frac{\|X\|_F}{\sqrt{n}} = 27.71$ قبل التطبيع، و 1 بعده. الخطوة 2: قبل: $45.25 \times 27.71 = 1253.9$؛ بعد: 45.25. النتيجة: تطبيع المدخلات يقلّص الحدّ بنحو 7.27 ضعفاً. الربط بالذكاء الاصطناعي: يبرّر تطبيع الدفعات وتطبيع الطبقات من منظور نظري لا تجريبي فقط.

مثال (3.34-7): نموذج لغوي بهامش ضيّق المعطيات: تضمينات معيّرة، $L = 12$، $\|W_l\|_\sigma = 2$، $\gamma = 0.3$، $n = 5 \times 10^4$. المطلوب: قيمة الحدّ. الحل: الخطوة 1: $\prod \|W_l\|_\sigma = 2^{12} = 4096$، و $L^{3/2} = 12^{1.5} = 41.569$. الخطوة 2: الحدّ $= \frac{41.569 \times 4096}{0.3} = \frac{170267}{0.3} = 5.68 \times 10^5$. النتيجة: الهامش الضيّق ($\gamma = 0.3$) مكلف جدّاً: يضاعف الحدّ 67.1 ضعفاً مقابل $\gamma = 0.5$ فقط. الربط بالذكاء الاصطناعي: النماذج اللغوية تدرَّب بهوامش صغيرة على مفردات ضخمة، فحدودها ضعيفة.

مثال (3.34-8): متى يصير الحدّ المعياري غير فارغ؟ المعطيات: شبكة ضحلة $L = 2$ بمعايير طيفية $1 =$ وهامش كبير $\gamma = 4$ (مُخرَج مُقاس). المطلوب: قيمة الحدّ. الحل: الخطوة 1: $L^{3/2} = 2^{1.5} = 2.828$. الخطوة 2: الحدّ $= \frac{2.828 \times 1}{4} = 0.707$. النتيجة: الحدّ $1 >$ ⇒ **غير فارغ**: الحدود المعيارية يمكن أن تكون ذات معنى في الأنظمة الضحلة واسعة الهامش. الربط بالذكاء الاصطناعي: يفسّر نجاح تحليل النظم الخطّية والشبكات الضحلة نظريّاً مقابل صعوبة العميقة.

مثال (3.34-9): التسعير المالي بميزات مؤشّرة المعطيات: 20 ميزة معيّرة ($\|x_i\|_2 = \sqrt{20} = 4.472$)، $L = 6$، $\|W_l\|_\sigma = 1.5$، $\gamma = 0.25$. المطلوب: قيمة الحدّ. الحل: الخطوة 1: $\prod \|W_l\|_\sigma = 1.5^6 = 11.391$، و $L^{3/2} = 6^{1.5} = 14.697$. الخطوة 2: الحدّ $= \frac{4.472 \times 14.697 \times 11.391}{0.25} = \frac{748.7}{0.25} = 2995$. النتيجة: الحدّ فادح؛ والسبب الرئيسي الهامش الضيّق $\gamma = 0.25$ وتراكم ستّ طبقات. الربط بالذكاء الاصطناعي: في المالية تُفضَّل النماذج الضحلة القابلة للتفسير؛ والنظرية تؤيّد ذلك.

مثال (3.34-10): تحكّم روبوتي بمساحة حالة صغيرة المعطيات: متّجهات حالة معيّرة بـ $\|x_i\|_2 = 3$، $L = 4$، $\|W_l\|_\sigma = 2$، $\gamma = 1.0$. المطلوب: قيمة الحدّ. الحل: الخطوة 1: $\prod \|W_l\|_\sigma = 2^4 = 16$، و $L^{3/2} = 4^{1.5} = 8$. الخطوة 2: الحدّ $= \frac{3 \times 8 \times 16}{1} = 384$. النتيجة: الحدّ كبير؛ العلاج النظري: تقليص المعيار الطيفي إلى $1 \approx$ يعطي 24 بدل 384. الربط بالذكاء الاصطناعي: الاستقرار في الروبوتات يقابله نظريّاً صغر المعيار الطيفي لسياسة التحكّم.

مثال (3.34-11): كشف احتيال بميزات متناثرة المعطيات: $\|x_i\|_2 = 1$، $L = 10$، $\|W_l\|_\sigma = 1.1$، $\gamma = 0.5$. المطلوب: قيمة الحدّ، وأثر تقليص كلّ معيار إلى 1.02. الحل: الخطوة 1: $\prod = 1.1^{10} = 2.594$، و $L^{3/2} = 10^{1.5} = 31.623$ ⇒ الحدّ $= \frac{31.623 \times 2.594}{0.5} = 164.0$. الخطوة 2: مع $1.02^{10} = 1.219$ ⇒ الحدّ $= \frac{31.623 \times 1.219}{0.5} = 77.1$. النتيجة: تحسين طفيف (من 10.1 إلى 02.1) في كلّ طبقة يقلّص الحدّ إلى النصف تقريباً. الربط بالذكاء الاصطناعي: حساسية الحدّ للتراكم الطبقي تجعل التطبيع الطيفي أهمّ كلّما زاد العمق.

مثال (3.34-12): نموذج لغوي عميق جدّاً المعطيات: $L = 32$، $\|W_l\|_\sigma = 1.05$، $\gamma = 0.1$. المطلوب: قيمة الحدّ. الحل: الخطوة 1: $\prod = 1.05^{32} = e^{32 \ln 1.05} = e^{1.5613} = 4.765$، و $L^{3/2} = 32^{1.5} = 181.02$. الخطوة 2: الحدّ $= \frac{181.02 \times 4.765}{0.1} = 8626$. النتيجة: عقوبة العمق $L^{3/2}$ هي المسيطرة هنا (181 مقابل 6.22 في شبكة من 8 طبقات). الربط بالذكاء الاصطناعي: يبرّر أهمّية التطبيع في كلّ طبقة في النماذج العميقة جدّاً (تطبيع مسبق مقابل تطبيع لاحق).

مثال (3.34-13): تنظيم صريح مقابل تطبيع طيفي المعطيات: شبكة $L = 8$، $\gamma = 0.5$: الخيار الأوّل تنظيم يخفض المعايير إلى 1.5، والثاني تطبيع طيفي يفرض 1. المطلوب: مقارنة الحدّين. الحل: الخطوة 1: الأوّل: $\frac{22.627 \times 25.629}{0.5} = 1160$. الخطوة 2: الثاني: $\frac{22.627 \times 1}{0.5} = 45.25$. الخطوة 3: الفرق $= 25.6 = 1160/45.25$ ضعفاً. النتيجة: التطبيع الطيفي أقوى نظريّاً لأنّه يضبط المعيار مباشرة بدل ضبطه جبريّاً عبر الخسارة. الربط بالذكاء

الاصطناعي: هذا أحد أسباب شيوع التطبيع الطيفي في التدريب المقاوِم.

مثال (14-3.34): تطبيع المدخلات مقابل تطبيع الأوزان المعطيات: الشبكة المرجعية بمعايير $1 = \gamma = 0.5$ و $\|x_i\| = 27.71$). المطلوب: أيّ التطبيعين أنجع؟ الحل: الخطوة 1: تطبيع المدخلات وحده: الحدّ من 1253.9 إلى 45.25 (عامل 7.27). الخطوة 2: تطبيع الأوزان وحده: الحدّ من 1253.9 إلى $1253.9/6561 = 0.191$ (إن كانت المعايير 3). النتيجة: تطبيع الأوزان أنجع هنا لأنّ الأثر طُبِّق على 8 طبقات بالضرب. الربط بالذكاء الاصطناعي: يبرّر الجمع بين تطبيع المدخلات وتطبيع الأوزان في الممارسة الحديثة.

مثال (15-3.34): لماذا لا ينفجر الحدّ مع زيادة العرض؟ المعطيات: الشبكة المرجعية المطبّعة طيفياً، نزيد عرض الطبقات من 512 إلى 4096 (ثمانية أضعاف المعلمات). المطلوب: أثر ذلك على الحدّ المعياري وعلى بُعد VC. الحل: الخطوة 1: الحدّ (8.34) يعتمد على $\prod \|W_l\|_\sigma$ لا على أبعاد المصفوفات $\Rightarrow$ يبقى 45.25. الخطوة 2: بُعد VC من رتبة $\Omega(WL) \Rightarrow$ يتضاعف نحو 8 مرّات. الخطوة 3: حدّ 2.34 يبقى فارغاً، والحدّ المعياري لا يتأثّر. النتيجة: الحدود المعيارية هي أوّل حدود تصمد أمام زيادة العرض — وهذا سبب تاريخي لأهمّيتها. الربط بالذكاء الاصطناعي: يهيّئ للنظرية 8.34 (نظام العرض اللانهائي) حيث يذهب العرض إلى اللانهاية.

أخطاء شائعة

- قراءة الرقم الناتج من (6.34) بوصفه تقديراً لخطر الاختبار (هو حدّ أعلى فضفاض، قيمته في الاتجاه).
- نسيان حذف الثوابت واللوغاريتمات في $\tilde{O}$ ثمّ مقارنة الحدود بين أبحاث مختلفة.
- توقّع أن يفسّر الحدّ وحده سبب نجاح الشبكات (هو يفسّر اتجاه التحسين لا حجم النجاح).
- الظنّ أنّ التطبيع الطيفي يقلّل عدد المعلمات (هو يقلّل المعيار الطيفي فقط).
- استخدام هامش $\gamma = 0$ أو هامش غير مُقاس ثمّ ادّعاء عدم فائدة الحدّ.
- تجاهل $\|X\|_F$: تطبيع المدخلات جزء من الحدّ لا تفصيل هندسي.

المبرهنة (مكأليستر 1999، ماورر 2004): ليكن P توزيعاً قبليّاً على فضاء الفرضيات $\mathcal{H}$ **مستقلّاً عن العيّنة**، وليكن Q أيّ توزيع بعدي (يجوز أن يعتمد على S). نعرّف

$$R(Q) = \mathbb{E}_{h\sim Q}\big[R(h)\big], \qquad \hat{R}_S(Q) = \mathbb{E}_{h\sim Q}\big[\hat{R}_S(h)\big] \tag{9.34}$$

فباحتمال $\geq 1-\delta$ على سحب S، **لكلّ** Q معاً:

$$R(Q) \leq \hat{R}_S(Q) + \sqrt{\frac{\mathrm{KL}(Q\|P) + \ln\!\big(2n/\delta\big)}{2n}} \tag{10.34}$$

وصيغة ماورر المضبوطة بتباعد برنولّي أصغر:

$$\mathrm{kl}\big(\hat{R}_S(Q)\,\|\,R(Q)\big) \leq \frac{\mathrm{KL}(Q\|P) + \ln\!\big((n+1)/\delta\big)}{n}, \qquad \mathrm{kl}(q\|p) = q\ln\frac{q}{p} + (1-q)\ln\frac{1-q}{1-p} \tag{11.34}$$

ولتوزيعين غاوسيّين متّحدي المركز $Q = \mathcal{N}(w, \sigma^2 I_p)$ و $P = \mathcal{N}(0, \sigma^2 I_p)$:

$$\mathrm{KL}(Q\|P) \;=\; \frac{\|w\|_2^2}{2\sigma^2} \tag{12.34}$$

النتيجة الحاسمة: الحدّ لا يعتمد على عدد معلمات الشبكة p إلا عبر KL؛ فمع $\mathrm{KL} = 500$ و $n = 5 \times 10^4$ يصير الهامش

$$\sqrt{\frac{500 + \ln(2 \times 10^6)}{10^5}} \;=\; \sqrt{\frac{514.51}{10^5}} \;=\; 0.0717 \;<\; 1 \tag{13.34}$$

أي **غير فارغ**، بينما مع $\mathrm{KL} = 10^7$ و $n = 10^4$ يصير $\sqrt{\frac{10^7 + 12.90}{2\times 10^4}} = \sqrt{500.0} = 22.36$ أي فارغ.

جدول الرموز

الرمز	المعنى	ملاحظة
P	توزيع قبلي قبل رؤية البيانات	شرط الاستقلال عن S
Q	توزيع بعدي بعد التعلّم	عادةً غاوسي حول الحلّ
$R(Q), \hat{R}(Q)$	خطري التوزيع البعدي	متوقّعات على Q
$\mathrm{KL}(Q\|P)$	تباعد (KL)	«سعة» التوزيع البعدي بالنت
$\mathrm{kl}(q\|p)$	تباعد برنوليّتين	أصغر من (KL) العامّة
σ^2	تباين البعدي الغاوسي	الضجيج المضاف للأوزان
$\|w\|^2$	مربّع معيار الحلّ	كلّما صغر قلّ الـ (KL)
غير فارغ	الهامش < 1	الحدّ ذو معنى

الرسم

<figure> الشكل<figcaption> 3.34: يضيق هامش (PAC-Bayes) مع صغر تباعد (KL) بين التوزيع البعدي والقبلي وكبر حجم العيّنة؛ وعند (KL) معقولة يعطي الحدّ أرقاماً غير فارغة على شبكات حقيقية.</figcaption>
</figure>

البرهان

الخطوة 1 (تبادل التوقّع): لأنّ P لا يعتمد على S، فإنّ $\mathbb{E}_{h\sim P}\big[e^{n\,\mathrm{kl}(\hat{R}(h)\|R(h))}\big] \;\le\; n+1$ بمعاملة تغيّر القياس (change of measure) تتبع مترابحة جنسن على اللوغاريتم. هذه هي اللبنة: الحدّ صحيح لأيّ h ثابت، ثمّ يُؤخذ المتوقّع تحت P.

الخطوة 2 (من P إلى Q بمعاملة تغيّر القياس):

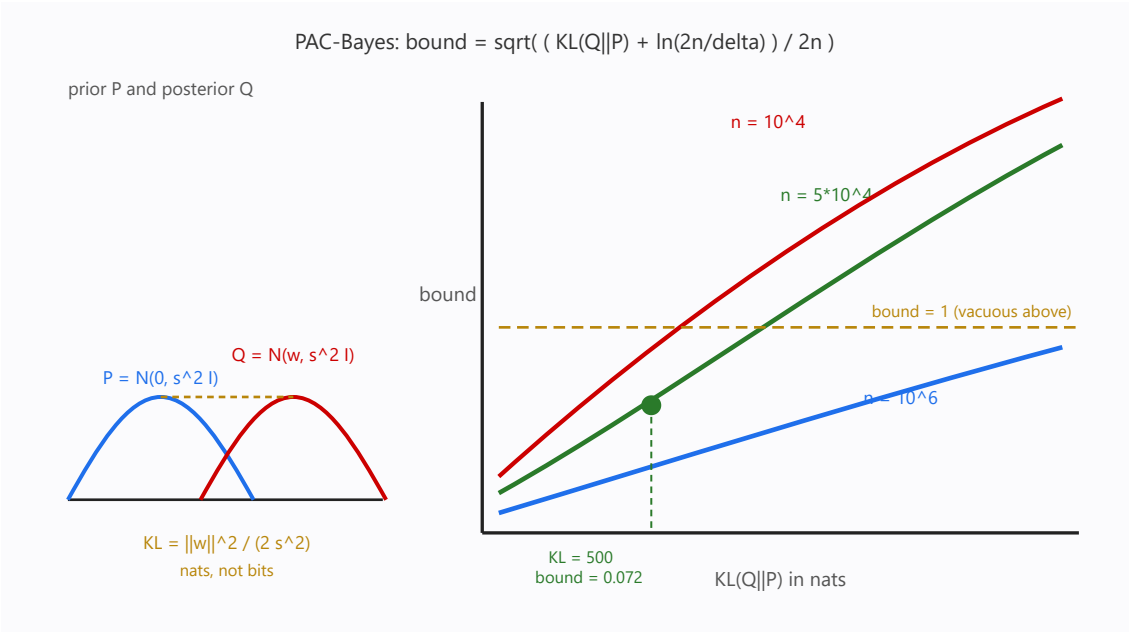
$$\mathbb{E}_{h\sim Q}\big[f(h)\big] \;\le\; \mathrm{KL}(Q\|P) \;+\; \ln \mathbb{E}_{h\sim P}\big[e^{f(h)}\big]$$

(مترابحة Donsker–Varadhan) في صيغتها الضعيفة)، وتُطبَّق على $f(h) = n\,\mathrm{kl}(\hat{R}(h)\|R(h))$. ■

الخطوة 3 (الجبر): نحصل على $\mathbb{E}_{h\sim Q}\big[n\,\mathrm{kl}(\hat{R}(h)\|R(h))\big] \le \mathrm{KL}(Q\|P) + \ln(n+1)$؛ وبجعل الفشل δ عبر ماركوف، ونقل اللوغاريتم خارج القوس بجنسن، نحصل على (11.34). ■

الخطوة 4 (صيغة مكأللستر): باستخدام $\mathrm{kl}(q\|p) \;\ge\; 2(p-q)^2$ (مترابحة بينكر) على (11.34) وضبط الثوابت نحصل على

$$R(Q) - \hat{R}(Q) \;\le\; \sqrt{\frac{\mathrm{KL}(Q\|P) + \ln(2n/\delta)}{2n}}$$



شكل ٣٤.٣٠: *
حد باك-بايز بدلالة تباعد كي-إل وحجم العينة

وهي (10.34). ■

الخطوة 5 (الغاوسي): لتوزيعين غاوسيّين متّحدي التباين $\sigma^2 I$ بمركزين w و 0: $\mathrm{KL} = \frac{1}{2}\left(\frac{\|w\|^2}{\sigma^2} - p + \frac{p\sigma^2}{\sigma^2}\right) = \frac{\|w\|^2}{2\sigma^2}$ $\Rightarrow$ (12.34). ■

الخطوة 6 (لماذا ينجح حيث يفشل بُعد VC؟): لأنّ السعة هنا تُقاس **للتوزيع البعدي المحقَّق** بعد التعلّم، لا للفضاء كلّه. شبكة بـ 10^7 معلمات قد تنتهي في توزيع بعدي قريب من القبلي (KL صغير)، فيكون الحدّ صغيراً. وهذا ما يجعل التحسين العددي للحدّ ممكناً: (Dziugaite) و (Roy) حسّنا (10.34) عدديّاً بالبحث عن Q و P يقلّلان الحدّ، فحصلا على حدود غير فارغة على (MNIST). ■

خمسة عشر مثالاً محلولاً

مثال (1-4.34): الحساب المرجعي غير الفارغ المعطيات: $\mathrm{KL} = 500$ نت، $n = 5 \times 10^4$، $\delta = 0.05$، $\hat{R}_S(Q) = 0.02$. المطلوب: الحدّ على خطر التعميم. الحل: الخطوة 1: $\ln(2n/\delta) = \ln(2 \times 10^6) = 14.509$. الخطوة 2: البسط $= 500 + 14.509 = 514.51$؛ المقام $= 2n = 10^5$. الخطوة 3: الهامش $= \sqrt{514.51/10^5} = \sqrt{5.1451 \times 10^{-3}} = 0.0717$. النتيجة: $R(Q) \le 0.02 + 0.0717 = 0.0917$ $\Rightarrow$ حدّ غير فارغ ومفيد. الربط بالذكاء الاصطناعي: هذا هو أوّل رقم في الفصل يمكن أن يُستخدم فعلاً في قرار هندسي.

مثال (2-4.34): الحالة الفارغة المعطيات: $\mathrm{KL} = 10^7$ نت (توزيع بعدي بعيد جدّاً عن القبلي)، $n = 10^4$، $\delta = 0.05$. المطلوب: الهامش. الحل: الخطوة 1: $\ln(2n/\delta) = \ln(4 \times 10^5) = 12.899$. الخطوة 2: البسط $= 10^7 + 12.9 = 1.0000013 \times 10^7$؛ المقام $= 2 \times 10^4$. الخطوة 3: الهامش $= \sqrt{500.0} = 22.36$. النتيجة: فارغ تماماً: «سعة» التوزيع البعدي تتجاوز ميزانية العيّنة. الربط بالذكاء الاصطناعي: الحدود البايزية ليست سحراً: إن أفرطت في الابتعاد عن القبلي دفعت الثمن.

مثال (3-4.34): حساب (KL) الغاوسي من معيار الحلّ المعطيات: شبكة $p = 10^7$ معلمة، $\|w\|_2^2 = 1000$، تباين البعدي $\sigma^2 = 1$. المطلوب: قيمة التباعد ونصيب المعلمة الواحدة. الحل: الخطوة 1: $\mathrm{KL} = \frac{\|w\|^2}{2\sigma^2} = \frac{1000}{2} = 500$

نت. الخطوة 2: نصيب المعلمة $500/10^7 = 5 \times 10^{-5}$ نت فقط. النتيجة: (KL) يقيس «المسافة بوحدات الانحراف المعياري» لا عدد الأبعاد، ولذلك لا ينفجر مع p. الربط بالذكاء الاصطناعي: يفسّر قدرة (PAC-Bayes) على التعامل مع ملايين المعلمات.

مثال (4-4.34): أثر تباين البعدي على التباعد المعطيات: الحلّ نفسه $\|w\|^2 = 1000$ لكن بتكميم/ضجيج أدقّ: $\sigma^2 = 0.01$ مقابل $\sigma^2 = 1$. المطلوب: التباعد في الحالتين. الحل: الخطوة 1: مع $\sigma^2 = 0.01$: $\mathrm{KL} = \frac{1000}{0.02} = 5\times10^4$ نت. الخطوة 2: مع $\sigma^2 = 1$: $\mathrm{KL} = 500$ نت. الخطوة 3: النسبة $100 = (=$ نسبة التباينين معكوسة). النتيجة: تضييق البعدي يرفع الثمن أُسّيّاً، التوازن بين $\hat{R}(Q)$ و (KL) هو لبّ التحسين البايزي. الربط بالذكاء الاصطناعي: يبرّر البحث العددي عن أفضل σ بدل اختياره اعتباطاً.

مثال (5-4.34): صيغة (kl) المضبوطة تعطي ما هو أحسن بكثير المعطيات: $\hat{R}_S(Q) = 0$، $\mathrm{KL} = 500$، $n = 5 \times 10^4$، $\delta = 0.05$. المطلوب: الحدّ من (11.34) ومقارنته بـ (10.34). الحل: الخطوة 1: $\ln((n+1)/\delta) = \ln(10^6) = 13.816$؛ البسط $513.816 =$؛ $c = 513.816/5\times10^4 = 0.010276$. الخطوة 2: مع $\hat{R} = 0$: $R \le 1 - e^{-0.010276} = 0.010224 \Rightarrow \mathrm{kl}(0\|R) = -\ln(1-R) \le c$. الخطوة 3: صيغة مكألستر تعطي $0.0717 = 0.0717 + 0$؛ والصيغة المضبوطة تعطي 0.0102. النتيجة: تحسّن بنحو 7.0 ضعفاً: صيغة (kl) تستغلّ أنّ التوزيع البرنوليّ ليس غاوسيّاً. الربط بالذكاء الاصطناعي: عند معدّلات خطأ قريبة من الصفر تكون صيغة (kl) هي الخيار الصحيح دائماً.

مثال (6-4.34): أثر حجم العيّنة على الهامش المعطيات: $\mathrm{KL} = 500$، $\delta = 0.05$، و n يأخذ 10^4 ثم 5×10^4 ثم 10^6. المطلوب: الهامش في الحالات الثلاث. الحل: الخطوة 1: $n = 10^4$: $\ln(2n/\delta) = 12.899$؛ الهامش $= \sqrt{0.025645} = 0.1601$. الخطوة 2: $n = 5 \times 10^4$: الهامش $= \sqrt{512.899/2 \times 10^4} = 0.0717$ (المثال 1-4.34). الخطوة 3: $n = 10^6$: $\ln(2n/\delta) = 17.504$؛ الهامش $= \sqrt{517.504/2 \times 10^6} = \sqrt{2.5875 \times 10^{-4}} = 0.01609$. النتيجة: الهامش يتناقص بنحو $1/\sqrt{n}$: مضاعفة العيّنة 100 ضعفاً تقلّصه 10 أضعاف. الربط بالذكاء الاصطناعي: خلافاً لحدّ 2.34، هذا الحدّ **يتحسّن فعلاً** مع البيانات.

مثال (7-4.34): أثر مستوى الثقة المعطيات: $\mathrm{KL} = 500$، $n = 5 \times 10^4$، و δ من 0.05 إلى 0.01. المطلوب: تضخّم الهامش. الحل: الخطوة 1: $\ln(2n/0.01) = \ln(10^7) = 16.118$ مقابل $\ln(2 \times 10^6) = 14.509$. الخطوة 2: البسط من 514.51 إلى 516.12 (+0.31%). الخطوة 3: الهامش من 0.07173 إلى 0.07184. النتيجة: أثر شبه معدوم: لأنّ المقدار المهيمن هو (KL) لا اللوغاريتم. الربط بالذكاء الاصطناعي: في الحدود البايزية «القدرة الشرائية» كلّها في ميزانية الـ (KL).

مثال (8-4.34): ميزانية الـ (KL) المسموحة لحدّ مستهدف المعطيات: $n = 5 \times 10^4$، $\delta = 0.05$، ونريد هامشاً ≤ 0.05. المطلوب: أكبر (KL) مسموح. الحل: الخطوة 1: $\frac{\mathrm{KL}+\ln(2n/\delta)}{2n} \le 0.0025 \Rightarrow \mathrm{KL} \le 0.0025 \times 10^5 - 14.509$. الخطوة 2: $\mathrm{KL} \le 250 - 14.509 = 235.5$ نت. النتيجة: ميزانية ضيّقة (235 نت)، وهي ما يجعل تحسين الحدّ عددّياً مسألةً صعبة. الربط بالذكاء الاصطناعي: يفسّر لماذا نجحت تجارب (Dziugaite–Roy) على (MNIST) وصعُب تكرارها على مجموعات أصعب.

مثال (9-4.34): شبكة رؤية بتوزيع بعدي غاوسي المعطيات: شبكة $p = 1.4 \times 10^6$، $\|w\|^2 = 40$، $\sigma = 0.02 \Rightarrow \sigma^2 = 4 \times 10^{-4}$، $n = 5 \times 10^4$. المطلوب: الحدّ. الحل: الخطوة 1: $\mathrm{KL} = \frac{40}{2\times4\times10^{-4}} = \frac{40}{8\times10^{-4}} = 5 \times 10^4$ نت. الخطوة 2: البسط $50014.5 = 50000 + 14.509$؛ المقام $10^5 =$. الخطوة 3: الهامش $= \sqrt{0.500145} = 0.7072$. النتيجة: الحدّ $1 <$ لكنّه ضعيف، السبب: σ صغير جدّاً فدفعنا ثمناً باهظاً في (KL). الربط بالذكاء الاصطناعي: تحسين σ عددّياً (لا اختياره بالحدس) هو جوهر الطريقة البايزية العملية.

مثال (10-4.34): نموذج لغوي كبير ببيانات ضخمة المعطيات: $p = 7 \times 10^9$، $\|w\|^2 = 100$، $\sigma^2 = 10^{-4}$، $n = 10^9$ مثال تدريبي. المطلوب: الهامش. الحل: الخطوة 1: $\mathrm{KL} = \frac{100}{2\times10^{-4}} = 5 \times 10^5$ نت. الخطوة 2:

24.412 $= \ln(4 \times 10^{10}) = \ln(2n/\delta)$؛ البسط 500024.4 =؛ المقام 2×10^9 =. الخطوة 3: الهامش 0.01581 $= \sqrt{2.50012 \times 10^{-4}}$ =. النتيجة: حدّ غير فارغ رغم المليارات من المعلمات، لأنّ n هائل و (KL) معقول. الربط بالذكاء الاصطناعي: مع افتراض i.i.d. (وهو محلّ شكّ في النماذج اللغوية) يعطي (PAC-Bayes) أرقاماً قابلة للنقاش.

مثال (11-4.34): تشخيص طبي بعيّنة صغيرة المعطيات: $n = 2000$ صورة أشعة، KL = 300 نت، $\hat{R}_S(Q) = 0.03$. المطلوب: الحدّ. الحل: الخطوة 1: $\ln(2n/\delta) = \ln(8 \times 10^4) = 11.290$. الخطوة 2: البسط 311.29 =؛ المقام 4000 = $\Rightarrow$ الهامش $\sqrt{0.077823} = 0.2790$ =. النتيجة: $R(Q) \le 0.03 + 0.279 = 0.309$: غير فارغ لكن فضفاض؛ العيّنة الصغيرة هي القيد. الربط بالذكاء الاصطناعي: في الطبّ، زيادة حجم العيّنة المؤسّسية أنجع من أيّ تلاعب بالمعمارية.

مثال (12-4.34): مخاطر ائتمانية المعطيات: $n = 5000$ ملفّ، KL = 1000 نت، $\hat{R}_S(Q) = 0.05$. المطلوب: الحدّ والتوصية. الحل: الخطوة 1: $\ln(2n/\delta) = \ln(2 \times 10^5) = 12.206$؛ البسط 1012.21 =؛ المقام 10^4 =. الخطوة 2: الهامش $\sqrt{0.101221} = 0.3182$ = $\Rightarrow R \le 0.368$. النتيجة: الحدّ فضفاض جدّاً لقرار ائتماني؛ التوصية: تقليص (KL) بتوسيع σ أو تقليل $\|w\|$. الربط بالذكاء الاصطناعي: الحدود تُستخدم في المالية كـ«مؤشّر تحذير» لا كضمان ملزم.

مثال (13-4.34): روبوتات بعيّنة مختبرية المعطيات: $n = 800$ تجربة، KL = 50 نت، $\hat{R}_S(Q) = 0.10$. المطلوب: الحدّ. الحل: الخطوة 1: $\ln(2n/\delta) = \ln(32000) = 10.374$؛ البسط 60.374 =؛ المقام 1600 =. الخطوة 2: الهامش $\sqrt{0.037733} = 0.1943$ = $\Rightarrow R \le 0.294$. النتيجة: حدّ ذو معنى رغم صغر العيّنة، بفضل (KL) صغير جدّاً. الربط بالذكاء الاصطناعي: في الروبوتات يكون الحلّ قريباً من القبلي (حركة ملساء) فيصغر التباعد طبيعيّاً.

مثال (14-4.34): كشف اختراق على نطاق واسع المعطيات: $n = 10^6$ حدث، KL = 2000 نت، $\hat{R}_S(Q) = 0.01$. المطلوب: الحدّ. الحل: الخطوة 1: $\ln(2n/\delta) = \ln(4 \times 10^7) = 17.504$؛ البسط 2017.50 =؛ المقام 2×10^6 =. الخطوة 2: الهامش $\sqrt{1.00875 \times 10^{-3}} = 0.03176$ = $\Rightarrow R \le 0.0418$. النتيجة: حدّ قويّ: البيانات الضخمة تعوّض كبر التباعد. الربط بالذكاء الاصطناعي: في الأمن السيبراني تتوفّر البيانات عادةً، فـ (PAC-Bayes) مناسب نظريّاً.

مثال (15-4.34): قراءة منهجية — لماذا ينجح (PAC-Bayes) المعطيات: حدّ (2.34) فارغ (3.33)، وحدّ (4.34) غير فارغ (0.0917) على المسألة نفسها تقريباً. المطلوب: التفسير البنيوي. الحل: الخطوة 1: حدّ 2.34 يقيس سعة الفضاء $\mathcal{H}$ (أسوأ الحالات على كلّ الفرضيات). الخطوة 2: حدّ 4.34 يقيس سعة **توزيع** واحد محقَّق Q: أي «كم بتّاً من المعلومات استخرجنا من العيّنة». الخطوة 3: لأنّ (SGD) لا يستخرج كلّ ما يمكن استخراجه، يبقى Q قريباً من P، فيصغر (KL). النتيجة: إدخال التوزيع المحقَّق (لا الفضاء الممكن) هو الذي أنقذ الحدّ من الفَراغ. الربط بالذكاء الاصطناعي: هذه الفكرة تتكرّر في 5.34 (الوصف المضغوط) و 6.34 (الحلّ الذي يختاره المُحسِّن).

أخطاء شائعة

- اختيار قبلي P يعتمد على بيانات التدريب ثمّ تطبيق الحدّ (ينكسر شرط الاستقلال).
- الخلط بين kl (برنوليّ) و KL (عامّة) وبين معاملَي n و $2n$.
- الظنّ أنّ الحدّ على $R(Q)$ هو حدّ على خطر الشبكة الحتمية (الشبكة العشوائية مختلفة).
- تجاهل أنّ $\hat{R}(Q)$ يرتفع عادةً عند توسيع σ (مقايضة يجب تحسينها عدديّاً).

- استخدام KL بمقياس «النت» ثمّ مقارنته بأرقام بالبتّات (عامل $\ln 2$).
- افتراض أنّ الحدّ غير الفارغ يعني أنّ النموذج آمن للإنتاج (هو ضمان تحت فروض i.i.d.).

المبرهنة (أرورا وآخرون 2018 — صيغة مبسّطة): لتكن $\hat{h}$ شبكةً مُدرَّبة بعدد معلمات p. لو وُجد وصفٌ مضغوط للشبكة — أي رسالة من k معلمات (اختيار مؤشّرات + قيم مكمّمة) — يعيد بناء شبكة $\tilde{h}$ بحيث

$$\left|\hat{R}_S(\tilde{h}) - \hat{R}_S(\hat{h})\right| \;\le\; \gamma,$$

فباحتمال $\ge 1-\delta$ على سحب العيّنة:

$$R(\hat{h}) \;\le\; \hat{R}_S(\hat{h}) \;+\; \gamma \;+\; \tilde{O}\!\left(\sqrt{\frac{k\,\ln n}{n}}\right) \tag{14.34}$$

وإن أردنا حساب عدد الرسائل الممكنة صراحةً (اختيار k معلمة من p) نستخدم

$$\ln \binom{p}{k} \;\le\; k \ln \frac{e\,p}{k} \tag{15.34}$$

فتصير الصيغة $R \le \hat{R} + \gamma + \tilde{O}\big(\sqrt{(k \ln \frac{ep}{k} + \ln \frac{1}{\delta})/n}\big)$. وإذا خُزّنت كلّ معلمة مضغوطة بـ b بتّاً فإنّ عدد الرسائل هو 2^{kb}، فيعطي اتّحاد الاحتمالات

$$\varepsilon_{\text{quant}} \;=\; \sqrt{\frac{k\,b\,\ln 2 + \ln(2/\delta)}{2n}} \tag{16.34}$$

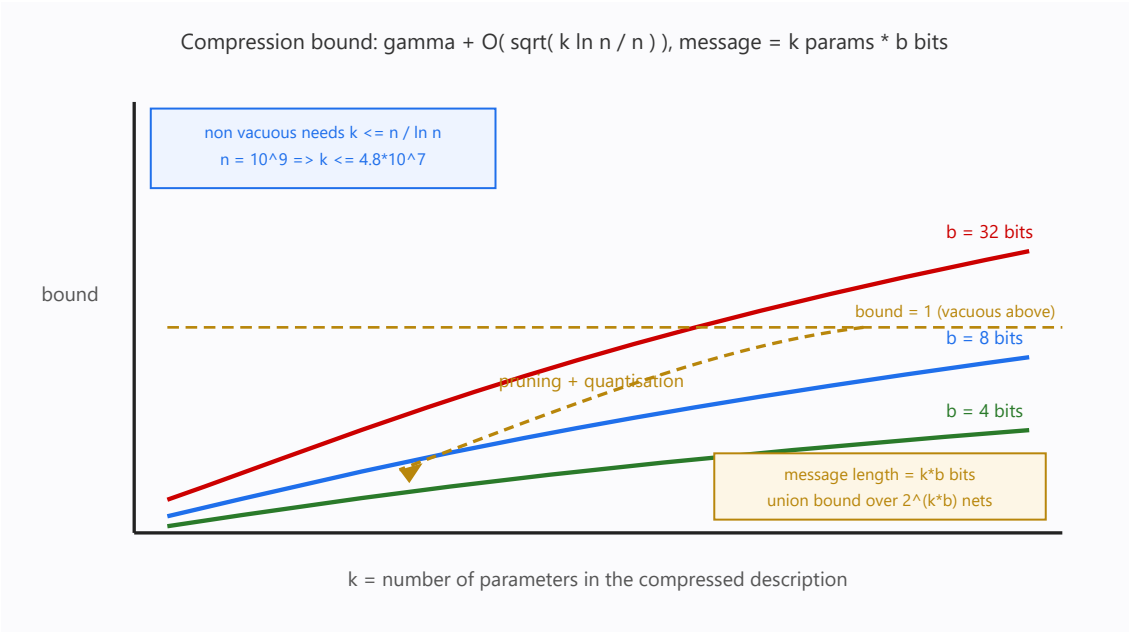
والصيغة الجامعة التي تُقرأ على أنّها «طول الوصف مقابل حجم العيّنة»:

$$R(\hat{h}) \;\le\; \hat{R}_S(\hat{h}) \;+\; \gamma \;+\; \tilde{O}\!\left(\sqrt{\frac{\text{طول الوصف بالنت} + \ln(1/\delta)}{n}}\right) \tag{17.34}$$

النتيجة: لا يظهر p في الحدّ؛ يظهر k (حجم الوصف الفعّال) و γ (خطأ الضغط). فالتقليم والتكميم والتقطير ليست حيلًا هندسية فحسب — هي في صلب حدّ التعميم.

جدول الرموز

الرمز	المعنى	ملاحظة
p	عدد معلمات الشبكة الأصلي	قد يكون 10^9
k	عدد معلمات الوصف المضغوط	$k \ll p$
γ	زيادة الخطر التجريبي بسبب الضغط	خطأ التقليم/التكميم
b	بتّات تخزين المعلمة الواحدة	32 أو 8 أو 4 أو 1
$\binom{p}{k}$	عدد اختيارات المؤشّرات	$\ln \binom{p}{k} \le k \ln \frac{ep}{k}$
2^{kb}	عدد الرسائل بعد التكميم	اتّحاد على 2^{kb} شبكة
طول الوصف	الميزانية المعلوماتية	يقابل (KL) في 4.34
تذكرة اليانصيب	وصف: مؤشّرات + تهيئة	مثال كلاسيكي على الضغط



شكل ٤٠٣٤: *
حد الضغط بدلالة عدد المعلمات المضغوطة والبتات

الرسم

<figure> الشكل<figcaption> 4.34: كلّما قلّ عدد معلمات الوصف k وقلّت بتّات التخزين b ضاق حدّ التعميم؛ التقليم والتكميم والتقطير تُقرأ نظريّاً بوصفها تقليصاً لطول الوصف لا لمساحة الذاكرة.</figcaption> </figure>

البرهان

الخطوة 1 (الوصف بوصفه متغيّراً عشوائياً): الرسالة المضغوطة اختيارٌ من M رسالة ممكنة، حيث $M = \binom{p}{k}$ (للاختيار) مضروباً في 2^{kb} (للقيم المكمّمة). كلّ رسالة تُعيّن شبكةً واحدة $\tilde{h}$، ولأنّ الرسالة قد اختيرت **بعد** رؤية العيّنة، لا يجوز تطبيق قانون الأعداد الكبرى على شبكة واحدة.

الخطوة 2 (اتّحاد على الرسائل): بتطبيق حدّ التقارب الموحّد (الفصل 30) على المجموعة المنتهية من الشبكات القابلة للوصف:

$$\mathbb{P}\Big[\exists \text{ رسالة } : \ |R(\tilde{h}) - \hat{R}(\tilde{h})| > \varepsilon\Big] \ \le \ 2M\, e^{-2n\varepsilon^2}$$

فنحصل على $\varepsilon = \sqrt{\frac{\ln(2M/\delta)}{2n}}$، وهو (16.34) عند $M = 2^{kb}$، وصيغة (15.34) عند $M = \binom{p}{k}$. ■

الخطوة 3 (نقل الحدّ من المضغوطة إلى الأصلية): بتعريف الضغط، $|\hat{R}(\tilde{h}) - \hat{R}(\hat{h})| \le \gamma$ على العيّنة؛ ولا علاقة مباشرة بين $R(\tilde{h})$ و $R(\hat{h})$، لكنّ الحدّ يُطبَّق على الشبكة **المضغوطة** التي ننشرها فعلاً، فنقرأه على أنّه حدّ لأداء المنظومة الكاملة: خطر تجريبي للأصلية + خطأ ضغط + هامش تعميم للوصف. ■

الخطوة 4 (القمم المسطّحة والضغط): إذا كان الحلّ في قمّة مسطّحة (flat minimum) — أي أنّ اضطرابات الأوزان الصغيرة لا تغيّر الخطر التجريبي كثيراً — أمكن تقريب الأوزان (تكميم خشن) بخطأ γ صغير، فصغر b وبقي k كبيراً لكنّ طول الوصف kb تقلّص. وبهذا يرتبط استقرار (SGD) (الفصل 33) بحدود الضغط: الحلول المستقرّة هي الحلول القابلة للضغط. ■

الخطوة 5 (حدود الميزانية): الحدّ غير فارغ عملياً إذا كان $k \ln n \lesssim n$، أي $k \lesssim \frac{n}{\ln n}$: فالضغط يجب أن يكون جذرياً، لا تجميلياً. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.34): الحساب المرجعي لحدّ الضغط المعطيات: شبكة مقلّمة إلى $k = 10^3$ معلمة فعّالة بخطأ ضغط $\gamma = 0.02$، $n = 5 \times 10^4$. المطلوب: حدّ التعميم من (14.34). الحل: الخطوة 1: $\ln n = \ln(5 \times 10^4) = 10.8198$. الخطوة 2: $k \ln n = 1.08198 \times 10^4$. الخطوة 3: الحدّ $\frac{k \ln n}{n} = \frac{10819.8}{5 \times 10^4} = 0.21640$ ⇒ الجذر $0.46519 = \hat{R} + 0.02 + 0.4652$. النتيجة: مع $\hat{R} = 0.02$ يصير الحدّ 0.505: فضفاض لكنه **أصغر من 1** بعكس حدّ 2.34. الربط بالذكاء الاصطناعي: الضغط الجذري (ألف معلمة فقط) هو ما يصنع الفرق لا الضغط المعتدل.

مثال (2-5.34): أثر حجم العيّنة على حدّ الضغط المعطيات: الوصف نفسه ($k = 10^3$، $\gamma = 0.02$) مع $n = 10^6$. المطلوب: الحدّ الجديد. الحل: الخطوة 1: $\ln(10^6) = 13.8155 \Rightarrow k \ln n = 1.38155 \times 10^4$. الخطوة 2: $\frac{13815.5}{10^6} = 0.0138155$ ⇒ الجذر $0.11754 = \hat{R} + 0.02 + 0.1175$. الخطوة 3: الحدّ $0.11754 = \hat{R} + 0.02 + 0.1175$. النتيجة: الهامش تقلّص من 0.4652 إلى 0.1175 (نحو $1/\sqrt{n}$ كما في كلّ الحدود الصحيحة). الربط بالذكاء الاصطناعي: خلافاً لحدّ 2.34، هذه العائلة تستجيب للبيانات.

مثال (3-5.34): التقليم مع حساب عدد الرسائل المعطيات: $p = 10^8$ معلمة، تقليم إلى $k = 10^4$، $n = 10^6$، $\gamma = 0.03$. المطلوب: الحدّ بصيغة (15.34). الحل: الخطوة 1: $\frac{ep}{k} = \frac{2.71828 \times 10^8}{10^4} = 2.71828 \times 10^4 \Rightarrow \ln = 10.2103$. الخطوة 2: $k \ln \frac{ep}{k} = 10^4 \times 10.2103 = 1.02103 \times 10^5$. الخطوة 3: $\frac{1.02103 \times 10^5}{10^6} = 0.102103 \Rightarrow$ الجذر $0.31954 = \hat{R} + 0.03 + 0.3195$. النتيجة: الحدّ $\hat{R} + 0.03 + 0.3195 =$: أفضل من صيغة $k \ln n$ لأنّها تحسب «أيّ» الأوزان أيضًا. الربط بالذكاء الاصطناعي: تذكرة اليانصيب (مؤشّرات + تهيئة) تدخل في هذه الميزانية بالضبط.

مثال (4-5.34): التكميم من 32 بتّاً إلى 4 بتّات المعطيات: $k = 10^4$ معلمة، $n = 5 \times 10^4$، $\delta = 0.05$. المطلوب: الهامش قبل التكميم وبعده، ونسبة التحسّن. الحل: الخطوة 1: قبل ($b = 32$): $kb \ln 2 = 10^4 \times 32 \times 0.69315 = 2.21808 \times 10^5$؛ $\frac{\cdot}{2n} = \frac{2.21808 \times 10^5}{10^5} = 2.21808$؛ الجذر $1.48932 =$. الخطوة 2: بعد ($b = 4$): $kb \ln 2 = 27726$؛ $\frac{\cdot}{10^5} = 0.27726$؛ الجذر $0.52656 =$. الخطوة 3: النسبة $= \frac{1.48932}{0.52656} = \sqrt{8} = 2.828$. النتيجة: التكميم إلى ربع العدد الأصلي من البتّات يقلّص الحدّ بعامل نسبة الضغط $\sqrt{}$ لا بنسبتها. الربط بالذكاء الاصطناعي: التكميم يحسّن التعميم نظرياً بعامل الجذر التربيعي فقط — لا أكثر.

مثال (5-5.34): التكميم الثنائي (شبكة بتّ واحد) المعطيات: $k = 10^5$ معلمة، $b = 1$، $n = 5 \times 10^4$. المطلوب: الهامش. الحل: الخطوة 1: $kb \ln 2 = 10^5 \times 0.69315 = 69315$. الخطوة 2: $\frac{69315}{10^5} = 0.69315 \Rightarrow$ الجذر $0.83255 =$. النتيجة: حدّ قريب من الفَراغ (833.0) رغم أنّ الشبكة مكمّمة بأقصى ما يمكن. الربط بالذكاء الاصطناعي: التكميم وحده لا يكفي إذا بقي عدد المعلمات كبيراً؛ الاثنان معاً (k و b) هما الميزانية.

مثال (6-5.34): التقطير (distillation) بوصفه ضغطاً المعطيات: معلّم $p = 10^8$، طالب $k = 10^4$ معلمة بخطأ تقليد $\gamma = 0.05$، $n = 10^6$. المطلوب: حدّ الطالب. الحل: الخطوة 1: $k \ln n = 10^4 \times 13.8155 = 1.38155 \times 10^5$. الخطوة 2: $\frac{1.38155 \times 10^5}{10^6} = 0.138155 \Rightarrow$ الجذر $0.37172 =$. الخطوة 3: الحدّ $\hat{R} + 0.05 + 0.3717 =$. النتيجة: الطالب يتمتّع بحدّ أضيق من المعلّم بمقدار كبير؛ هذه قراءة نظرية لنجاح التقطير. الربط بالذكاء الاصطناعي: يفسّر لماذا يعمل التقطير حتى حين يكون خطأ التدريب متساوياً تقريباً.

مثال (7-5.34): نموذج تشخيصي على جهاز طرفي (صحة) المعطيات: نموذج مضغوط $k = 5 \times 10^4$ معلمة، $\gamma = 0.02$، $n = 10^6$ صورة. المطلوب: الحدّ، والتوصية. الحل: الخطوة 1: $k \ln n = 5 \times 10^4 \times 13.8155 = 6.90775 \times 10^5$. الخطوة 2: $\frac{6.90775 \times 10^5}{10^6} = 0.690775 \Rightarrow$ الجذر $0.83113 =$. الخطوة 3: الحدّ $\hat{R} + 0.02 + 0.8311 = \Rightarrow$

فضفاض. النتيجة: للحدّ أن يكون مفيداً يجب النزول إلى $k \approx 5\times10^3$ (الجذر يصير 0.263). الربط بالذكاء الاصطناعي: في الأجهزة الطبية المحمولة يلتقي قيد الذاكرة مع قيد النظرية.

مثال (8-5.34): نموذج ائتماني مضغوط (مالية) المعطيات: $k = 500$ معلمة (قواعد قابلة للتفسير)، $\gamma = 0.01$، $n = 10^5$ طلب. المطلوب: الحدّ. الحل: الخطوة 1: $k\ln n = 5756.47 \Rightarrow \ln(10^5) = 11.5129$. الخطوة 2: $\frac{5756.47}{10^5} = 0.0575647 \Rightarrow$ الجذر 0.23993 =. الخطوة 3: الحدّ $\hat{R} + 0.01 + 0.2399$ =. النتيجة: حدّ ذو معنى: النماذج القابلة للتفسير تدفع ثمناً ضئيلاً في ميزانية الضغط. الربط بالذكاء الاصطناعي: المتطلّب التنظيمي للتفسيرية متوافق مع النظرية الإحصائية هنا.

مثال (9-5.34): سياسة روبوتية مضغوطة المعطيات: $k = 100$ معلمة، $\gamma = 0.03$، $n = 2000$ مسار. المطلوب: الحدّ. الحل: الخطوة 1: $k\ln n = 760.09 \Rightarrow \ln(2000) = 7.6009$. الخطوة 2: $\frac{760.09}{2000} = 0.380045 \Rightarrow$ الجذر 0.61648 =. الخطوة 3: الحدّ $\hat{R}+0.03+0.6165$ =. النتيجة: مقبول نسبياً لعيّنة صغيرة جدّاً، بفضل k الصغير. الربط بالذكاء الاصطناعي: السياسات المُعَلَّمة (مُتحكّمات بسيطة) لها ميزة نظرية في الروبوتات.

مثال (10-5.34): كشف اختراق بميزانية وصف صغيرة (أمن) المعطيات: $k = 2000$ معلمة، $\gamma = 0.01$، $n = 2\times10^5$ حدث. المطلوب: الحدّ. الحل: الخطوة 1: $k\ln n = 24412.2 \Rightarrow \ln(2\times10^5) = 12.2061$. الخطوة 2: $\frac{24412.2}{2\times10^5} = 0.122061 \Rightarrow$ الجذر 0.34937 =. الخطوة 3: الحدّ $\hat{R} + 0.01 + 0.3494$ =. النتيجة: حدّ مفيد: ميزانية الوصف صغيرة قياساً بحجم البيانات. الربط بالذكاء الاصطناعي: في الأمن يُفضَّل وصفٌ قصير (قواعد) على شبكة ضخمة لأسباب نظرية وعمليّة معاً.

مثال (11-5.34): ميزانية الضغط لنموذج لغوي كبير المعطيات: $n = 10^9$ مثال، ونريد هامشاً ≤ 1. المطلوب: أقصى k مسموح، ومقارنته بنموذج بـ 7×10^9 معلمة. الحل: الخطوة 1: الشرط $k \leq \frac{n}{\ln n} \Rightarrow \frac{k\ln n}{n} \leq 1$. الخطوة 2: $\ln(10^9) = 20.7233 \Rightarrow k \leq \frac{10^9}{20.7233} = 4.8255\times10^7$ معلمة. الخطوة 3: النموذج يتجاوز الميزانية بـ $\frac{7\times10^9}{4.8255\times10^7} = 145$ ضعفاً. النتيجة: حدود الضغط تفشل عددّياً على النماذج العملاقة إلا بضغط جذري (أو بتقطير إلى نموذج أصغر بكثير). الربط بالذكاء الاصطناعي: يفسّر لماذا تُقيَّم النماذج الكبيرة بالمعايير التجريبية لا بالحدود.

مثال (12-5.34): التكميم لا ينقذ النموذج العملاق المعطيات: $k = 7\times10^9$ معلمة مكمّمة إلى $b = 4$، $n = 10^9$، $\delta = 0.05$. المطلوب: الهامش. الحل: الخطوة 1: $kb\ln 2 = 7\times10^9\times4\times0.69315 = 1.94082\times10^{10}$. الخطوة 2: $\frac{1.94082\times10^{10}}{2\times10^9} = 9.7041 \Rightarrow$ الجذر 3.1151 =. النتيجة: فارغ: k كبير جدّاً، التكميم يقلّص العامل $\sqrt{b}$ فقط. الربط بالذكاء الاصطناعي: ضغط النماذج العملاقة يبقى مسألة هندسية (ذاكرة، زمن) لا مسألة نظرية تعميم.

مثال (13-5.34): التقليم بنسبة 99% مقابل 90% المعطيات: $10^6 = p$ معلمة، $n = 10^6$، الحالة الأولى $k = 10^5$ ($\gamma = 0.01$)، الثانية $k = 10^4$ ($\gamma = 0.03$). المطلوب: الحدّان. الحل: الخطوة 1: الأولى: $\frac{10^5\times13.8155}{10^6} = 1.38155 \Rightarrow$ الجذر 1.17539 = $\Rightarrow$ الحدّ $\hat{R} + 0.01 + 1.1754$ = (فارغ). الخطوة 2: الثانية: $\frac{10^4\times13.8155}{10^6} = 0.138155 \Rightarrow$ الجذر 0.37172 = $\Rightarrow$ الحدّ $\hat{R} + 0.03 + 0.3717$ =. الخطوة 3: رفع نسبة التقليم من 90% إلى 99% نقل الحدّ من الفَراغ إلى المعنى. النتيجة: «الضغط الجذري» عتبةٌ لا تدريج: الأثر يظهر عند أوامر من حيث الحجم. الربط بالذكاء الاصطناعي: يبرّر البحث عن تذاكر يانصيب شديدة التناثر لا تقليماً معتدلاً.

مثال (14-5.34): مقارنة ثلاث حدود على مسألة واحدة المعطيات: $n = 5\times10^4$، شبكة $p = 10^7$، $L = 8$، معايير طيفية 1 =، $\gamma_{\text{هامش}} = 0.5$، ووصف مضغوط $k = 10^3$ بخطأ ضغط 0.02. المطلوب: قيم الحدود 2.34 و 3.34 و 5.34. الحل: الخطوة 1: حدّ 2.34 (نموّ النموّ) 3.330 = $\Rightarrow$ فارغ. الخطوة 2: حدّ 3.34 (معياري) $\frac{8^{1.5}\times1}{0.5} = 45.25 \Rightarrow$ فارغ لكن متأثّر بالحلّ. الخطوة 3: حدّ 5.34 (الضغط) $0.4852 = 0.02 + 0.4652$ $\Rightarrow$ **غير فارغ**. النتيجة: الترتيب يعكس مبدأً عامّاً: كلّما أدخلنا مزيداً من معلومات الحلّ (المعايير $\leftarrow$ الوصف) ضاق

الحدّ. الربط بالذكاء الاصطناعي: الحدود ليست متنافسة بل متدرّجة في «كم تعرف عن الحلّ».

مثال (15-5.34): لماذا ينجح الضغط نظريّاً؟ المعطيات: شبكتان: الأولى $p = 10^7$ بوصف $k = 10^7$، والثانية $p = 10^7$ بوصف $k = 10^3$؛ $n = 5 \times 10^4$. المطلوب: الفرق في الحدّ والتفسير. الحل: الخطوة 1: الأولى: $\frac{10^7 \times 10.8198}{5 \times 10^4} = 2163.96 \Rightarrow$ الجذر $46.52 = \Rightarrow$ فارغ. الخطوة 2: الثانية: الجذر $0.4652 = \Rightarrow$ غير فارغ؛ الفرق $100 =$ ضعفاً ($= \sqrt{k_1/k_2}$). الخطوة 3: التفسير: الحدّ يقيس **طول الوصف** (كم بتّاً نحتاج لنقول من نحن) لا حجم الفضاء الذي نتحرّك فيه. النتيجة: النظرية تكافئ البخل في الوصف، وتعاقب البذخ فيه. الربط بالذكاء الاصطناعي: هذه الفكرة هي نفسها فكرة (KL) في 4.34 مكتوبة بلغة الترميز لا التوزيعات.

أخطاء شائعة

- حساب k بعدد الأوزان غير الصفرية فقط ونسيان مؤشّراتها (تدخل في $\ln \binom{p}{k}$).
- نسيان γ: ضغطٌ يرفع خطأ التدريب قد يضرّ أكثر مما ينفع.
- الظنّ أنّ التكميم يحسّن الحدّ بعامل $\sqrt{b}$ خطّيّاً (هو عامل الجذر التربيعي فقط).
- الخلط بين ضغط «الطراز» (architecture) ووصف «الأوزان» (الحدّ يتعامل مع الأوزان).
- تطبيق الحدّ على الشبكة الأصلية بدل المضغوطة (المنشورة فعلاً).
- تجاهل أنّ «الضغط» يجب أن يكون قابلاً لإعادة البناء من الرسالة وحدها.

المبرهنة (سودري وآخرون 2018؛ غوناسيكار وآخرون 2018): لتكن البيانات **قابلة للفصل خطّيّاً** بفاصل w، ولتُدرَّب خسارةٌ أُسّيّة أو لوغستية بمتوسط الخسارة $\frac{1}{n}\sum_i \ell(y_i w^\top x_i)$ بهبوط التدرّج. عندئذٍ يتقارب **اتّجاه** الحلّ إلى حلّ أقصى هامش:

$$\frac{w_t}{\|w_t\|_2} \longrightarrow w_{\mathrm{SVM}} = \arg\max_{\|w\|_2 \le 1} \min_i y_i\, w^\top x_i \tag{18.34}$$

بمعدّل نموّ للمعيار وتقاربٍ للهامش:

$$\|w_t\|_2 = \Theta(\log t), \qquad \gamma^\star - \gamma_t = O\!\left(\frac{1}{\log t}\right) \tag{19.34}$$

أمّا المُحسِّنات التكيفية فتنحاز نحو معيار آخر؛ فـ (Adam) والمُحسِّنات الشبيهة بالإشارة تنحو (تحت شروط نظرية) إلى

$$\frac{w_t}{\|w_t\|_\infty} \longrightarrow \arg\max_{\|w\|_\infty \le 1} \min_i y_i\, w^\top x_i \tag{20.34}$$

ولأنّ التوقّف المبكر يحدّ نموّ المعيار، فهو يعادل تنظيماً صريحاً (قاعدة إرشادية) بقوّة

$$\lambda_{\text{فعّال}} \approx \frac{2}{\eta\, t} \tag{21.34}$$

ويربط هذا كله بالحدّ المعياري (6.34) عبر الهامش المعيّر:

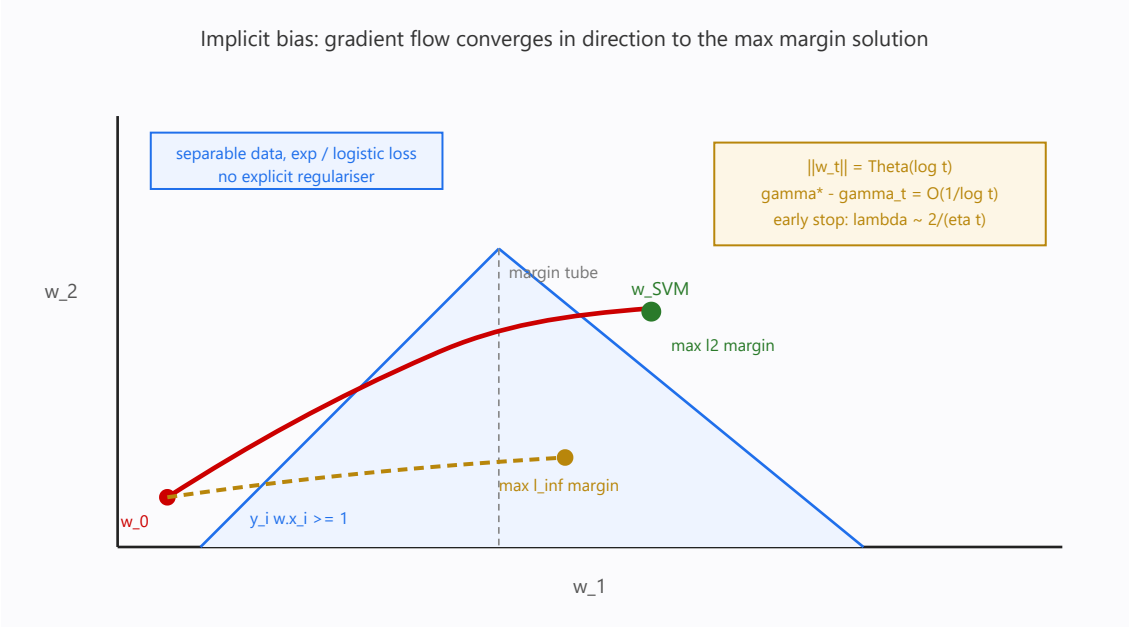
$$\bar{\gamma} = \frac{\gamma}{\prod_{l=1}^{L} \|W_l\|_\sigma} \qquad \Longrightarrow \qquad \text{ضاق الحدّ } \bar{\gamma} \text{ كلّما كبر} \tag{22.34}$$

جدول الرموز

الرمز	المعنى	ملاحظة
انحياز ضمني	تفضيلٌ للحلول بلا عقوبة صريحة	نابع من المُحسِّن والمعمارية
w_{SVM}	حلّ أقصى هامش (آلة الدعم)	يُستنتج لا يُفرض
$\|w_t\| = \Theta(\log t)$	نموّ بطيء جدّاً للمعيار	سبب استمرار تحسّن الهامش
γ_t	هامش التدريب عند الخطوة t	يقترب من $\gamma^\star$ ببطء
هامش ℓ_∞	هامش بمعيار القيمة القصوى	انحياز (Adam) التقريبي
$\eta,\ t$	حجم الخطوة وعددها	التوقّف المبكر = تنظيم
معيار نَوَوِيّ	مجموع القيم المفردة	انحياز تحليل المصفوفات
$\bar{\gamma}$	الهامش المعيّر	حلقة الوصل مع 3.34

الرسم

<figure> الشكل<figcaption> 5.34: يهبط مسار التدرّج بلا أيّ عقوبة صريحة نحو اتّجاه أقصى هامش؛ ويختلف



شكل ٥.٣٤: *
الانحياز الضمني لهبوط التدرج نحو أقصى هامش

الاتّجاه النهائي باختلاف المعيار الذي يصغّره المُحسِّن ضمنيّاً.</figcaption> </figure>

البرهان

الخطوة 1 (الخسارة لا تصل إلى الصفر أبداً): الخسارة الأُسّيّة $\ell(z) = e^{-z}$ موجبة دائماً، فلا يوجد مجال للصفر؛ لذلك يستمرّ التدرّج في الدفع نحو تكبير $y_i w^\top x_i$ لكلّ النقاط، أي يستمرّ $\|w_t\|$ في النموّ بدل التوقّف عند أيّ فاصل.

الخطوة 2 (اتّجاه التدرّج في الطور المتأخّر): حين يكبر $\|w_t\|$، يهيمن على التدرّج أصغرُ هامش (النقاط الأقرب للحدّ): $\nabla_w L \approx -\frac{1}{n}\sum_{i\in\mathcal{S}} c_i\, y_i x_i$ حيث $\mathcal{S}$ مجموعة نقاط الدعم. وبتحليل المتّجهات يتبع أنّ $\frac{w_t}{\|w_t\|}$ يصير توليفةً موجبة من متّجهات الدعم — وهو بالضبط شرط (KKT) لمسألة أقصى هامش (الفصل 21). ■

الخطوة 3 (معدّل النموّ): بتحليل متفاضلة $\|w_t\|$ على الخسارة الأُسّيّة يتبع $\|w_t\| \sim c\ln t$، ومنه $\gamma^\star - \gamma_t$

$(19.34) \Rightarrow O(1/\log t)$. التقارب بطيء جدّاً: مضاعفة عدد الخطوات لا تضيف للهامش إلا قدراً لوغاريتميّاً. ■

الخطوة 4 (المُحسِّنات التكيفية): (Adam) يقيس التدرّج بمقياس الجذر التربيعي للعزوم، فيقترب (في الحدّ) من هبوطٍ بأقصى معيار ℓ_∞ للهامش بدل ℓ_2؛ وبمبرهنة التآكل (steepest descent بمعيار $\|\cdot\|$) فإنّ الانحياز يكون نحو أصغر معيار مزدوج — ومن هنا (20.34). ■

الخطوة 5 (الربط بالتحيز-التباين، الفصل 30): التوقّف المبكر يحدّ $\|w\|$ فيحدّ «سعة» الحلّ الفعّالة: تحيّزٌ قليل + تباينٌ أقلّ من التدريب الكامل؛ ولذلك يعمل التوقّف المبكر بوصفه تنظيماً $L2$ بقوّة $\lambda \approx \frac{2}{\eta t}$ في النماذج الخطّية (علاقة إرشادية مشتقّة من مقارنة مسارَي التدرّج والتنظيم). ■

الخطوة 6 (الربط بـ 3.34): الحدّ المعياري يتناقص مع صغر $\prod_l \|W_l\|_\sigma$ وكبر γ؛ والانحياز الضمني يفعل الاثنين معاً: يكبر الهامش γ_t مع t، لكنّه يدفع المعايير للنموّ أيضاً؛ فالعائد الحدّي للتدريب الطويل يتناقص — وهذا يفسّر عمليّاً أنّ التعميم يتحسّن ثمّ يستقرّ ثمّ قد يتدهور. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.34): أقصى هامش في مسألة قابلة للفصل خطّيّاً المعطيات: ثلاث نقاط: $x_1 = (2,0)$ و $x_2 = (0,2)$ بوسم $+1$، و $x_3 = (-1,-1)$ بوسم -1. المطلوب: حلّ أقصى هامش الذي سينحو إليه التدرّج. الحل: الخطوة 1: القيود بهامش 1: $2w_1 \geq 1$ و $2w_2 \geq 1$ و $w_1 + w_2 \geq 1$. الخطوة 2: أصغر حلّ: $w = (0.5, 0.5)$ (يحقّق القيد الثالث بـ $1 \geq 1$). الخطوة 3: $\|w\|_2 = \sqrt{0.25+0.25} = 0.7071 \Rightarrow$ الهامش $= 1/0.7071 = 1.4142$.

النتيجة: يتّجه التدرّج نحو $(1,1)/\sqrt{2}$ دون أيّ عقوبة هامش صريحة في الخسارة. الربط بالذكاء الاصطناعي: الخسارة اللوغستية «تخفي» آلة دعم في داخلها.

مثال (2-6.34): (SGD) مقابل (Adam) — هامشان مختلفان المعطيات: نقطتان: $x_+ = (1,3)$ بوسم $+1$ و $x_- = (-10,-10)$ بوسم -1؛ القيود: $w_1 + 3w_2 \geq 1$ و $w_1 + w_2 \geq 0.1$. المطلوب: حلّ أصغر ℓ_2 وحلّ أصغر ℓ_∞. الحل: الخطوة 1: القيد الثاني ضعيف عند الحلّين المطلوبين، فالمقيّد هو $w_1 + 3w_2 \geq 1$. الخطوة 2: أصغر ℓ_2: نشترط $\max(w_1, w_2) = r$ و $w_1 + 3w_2 \leq 4r \Rightarrow r \geq 0.25 \Rightarrow w = (0.25, 0.25) \Rightarrow$ الهامش $= 4$. الخطوة 4: التحقّق: $\|w_{\ell_2}\|_\infty = 0.3 > 0.25$ و $\|w_{\ell_\infty}\|_2 = 0.3536 > 0.3162$. النتيجة: المُحسِّنان يختاران **اتّجاهين مختلفين**: $(1,3)$ مقابل $(1,1)$. الربط بالذكاء الاصطناعي: يفسّر اختلاف سلوك التعميم بين (SGD) و (Adam) على البيانات القابلة للفصل.

مثال (3-6.34): نموّ معيار الحلّ مع عدد الخطوات المعطيات: $\|w_t\|_2 \approx 0.5 \ln t$، نقارن $t = 10^3$ و $t = 10^5$. المطلوب: المعيار في الحالتين ونسبة النموّ. الحل: الخطوة 1: $\ln(10^3) = 6.9078 \Rightarrow \|w\| = 3.4539$. الخطوة 2: $\ln(10^5) = 11.5129 \Rightarrow \|w\| = 5.7565$. الخطوة 3: النسبة $5.7565/3.4539 = 1.667$ رغم مضاعفة الخطوات 100 مرّة. النتيجة: النموّ لوغاريتمي: التدريب مئة ضعف يكبّر المعيار 67.1 ضعفاً فقط. الربط بالذكاء الاصطناعي: يفسّر لماذا لا ينفجر التنظيم الضمني مع التدريب الطويل.

مثال (4-6.34): تقارب الهامش إلى حدّه الأقصى المعطيات: $\gamma^\star = 0.4$، و $\gamma_t = \gamma^\star - \frac{0.5}{\ln t}$. المطلوب: الهامش عند $t = 10^3$ و $t = 10^5$، ونسبة النقص المتبقّي. الحل: الخطوة 1: $t = 10^3$: $\gamma = 0.4 - \frac{0.5}{6.9078} = 0.4 - 0.07238 = 0.32762$ (نقص 18.1%). الخطوة 2: $t = 10^5$: $\gamma = 0.4 - \frac{0.5}{11.5129} = 0.4 - 0.04343 = 0.35657$ (نقص 10.9%). الخطوة 3: مضاعفة الخطوات 100 مرّة نقّصت الفجوة من 18.1% إلى 10.9% فقط. النتيجة: التقارب للهامش الأقصى بطيء جدّاً؛ التدريب

الطويل عائدٌ حدّي متضائل. الربط بالذكاء الاصطناعي: يبرّر اقتصادياً التوقّف المبكر قبل «الاستنزاف» الكامل للهامش.

مثال (6.34-5): التوقّف المبكر يعادل أيّ قوّة تنظيم؟ المعطيات: $\eta = 0.1$، نقارن التوقّف عند $t = 10^3$ و $t = 10^4$. المطلوب: قوّة التنظيم المكافئة بالقاعدة (21.34). الحل: الخطوة 1: $t = 10^3$: $\lambda \approx \frac{2}{0.1\times 10^3} = \frac{2}{100} = 0.02$. الخطوة 2: $t = 10^4$: $\lambda \approx \frac{2}{0.1\times 10^4} = \frac{2}{1000} = 0.002$. النتيجة: كلّما أطلنا التدريب ضعُف التنظيم المكافئ بعامل عشرة لكلّ عشر خطوات. الربط بالذكاء الاصطناعي: يفسّر أنّ إطالة التدريب بلا تقليل معدّل التعلّم = إضعاف التنظيم.

مثال (6.34-6): أثر التوقّف المبكر على الحدّ المعياري المعطيات: شبكة $L = 3$ بمعايير طبقية متساوية، والمعيار ينمو من 454.3 إلى 757.5 بين الوقفتيْن. المطلوب: تضخّم الحدّ (8.34) لو أطلنا التدريب. الحل: الخطوة 1: نسبة المعيار الطبقي $\frac{5}{3} = 1.667 = \frac{5.7565}{3.4539}$. الخطوة 2: الحدّ يتناسب مع الحاصل على الطبقات: التضخّم $\left(\frac{5}{3}\right)^3 = \frac{125}{27} = 4.63$. الخطوة 3: ولو كانت الشبكة $L = 8$: التضخّم $\left(\frac{5}{3}\right)^8 = 59.5$. النتيجة: إطالة التدريب ترفع الحدّ المعياري أُسّياً في عدد الطبقات. الربط بالذكاء الاصطناعي: التوقّف المبكر في الشبكات العميقة أهمّ منه في الشبكات الضحلة.

مثال (6.34-7): تحليل المصفوفات يختار الرتبة الصغرى المعطيات: إكمال مصفوفة 2×2 بمدخلات معلومة $(1,1) = 1$، $(1,2) = 1$، $(2,1) = 1$، ومجهول $(2,2) = z$. المطلوب: أيّ z يختاره تحليل المصفوفات (انحياز نَوَويّ) وأيّه يختاره أصغر معيار فوربنيوس؟ الحل: الخطوة 1: الخيار $z = 0$: القيم المفردة لـ $\begin{pmatrix}1 & 1\\ 1 & 0\end{pmatrix}$ هي 1.618 و $0.618 \Rightarrow$ المعيار النَّوويّ $= 2.236$، وفوربنيوس $= \sqrt{3} = 1.732$. الخطوة 2: الخيار $z = 1$: المصفوفة $\begin{pmatrix}1 & 1\\ 1 & 1\end{pmatrix}$ $\Rightarrow$ المعيار النَّوويّ $= 2$، وفوربنيوس $= 2$. الخطوة 3: أصغر نَوَويّ $\Rightarrow z = 1$ (رتبة 1)؛ أصغر فوربنيوس $\Rightarrow z = 0$. النتيجة: المُحسِّن يختار «أبسط بنية» لا «أصغر قيم»؛ والانحياز يعتمد على تمثيل المعلمات. الربط بالذكاء الاصطناعي: يفسّر ظاهرة الرتبة المنخفضة في تحليل المصفوفات والتضمينات.

مثال (6.34-8): حجم الدفعة والتسطيح المعطيات: تدريب بدفعة $B = 32$ ثم بدفعة $B = 1024$ بالحجم نفسه للخطوة. المطلوب: مقارنة «الضجيج التدريجي» وأثره. الحل: الخطوة 1: تباين تقدير التدرّج يتناسب عكسياً مع $B \Rightarrow$ النسبة $1024/32 = 32$. الخطوة 2: الدفعة الصغيرة تزور قمّةً أوسع (اضطراب أكبر يتحمّله الحلّ) $\Rightarrow$ قمّة مسطّحة. الخطوة 3: للحفاظ على الأثر نفسه عند رفع B نرفع η بالنسبة نفسها (قاعدة التحجيم الخطّي). النتيجة: حجم الدفعة جزء من الانحياز الضمني لا مجرّد إعداد أداء. الربط بالذكاء الاصطناعي: يربط هذا الفصل بالفصل 33 (الاستقرار) وبالنظرية 3.34 (المعايير).

مثال (6.34-9): هامش تشخيصي في التصوير الطبي المعطيات: شبكة $L = 6$ بضرب معايير $= 8$؛ هامش مقاس 0.15 بعد 100 حقبة و 0.22 بعد 500 حقبة. المطلوب: أثر تحسّن الهامش على الحدّ (8.34). الحل: الخطوة 1: $L^{3/2} = 6^{1.5} = 14.697$، البسط $= 14.697 \times 8 = 117.58$. الخطوة 2: مع $\gamma = 0.15$: الحدّ $= \frac{117.58}{0.15} = 783.9$. الخطوة 3: مع $\gamma = 0.22$: الحدّ $= \frac{117.58}{0.22} = 534.5$؛ تحسّن بنسبة 1.47. النتيجة: التدريب الأطول حسّن الهامش، لكنّه يكبّر المعايير أيضاً (المثال 6.34-6) — والمحصّلة تحدّد القرار. الربط بالذكاء الاصطناعي: القياس المزدوج (الهامش والمعايير) هو التشخيص الصحيح لا أحدهما.

مثال (6.34-10): انحدار لوجستي مالي قابل للفصل المعطيات: $\|w_t\| = 0.3\ln t$؛ نقارن $t = 500$ و $t = 5000$ خطوة. المطلوب: المعيار في الحالتين. الحل: الخطوة 1: $\ln(500) = 6.2146 \Rightarrow \|w\| = 1.8644$. الخطوة 2: $\ln(5000) = 8.5172 \Rightarrow \|w\| = 2.5552$. الخطوة 3: النسبة $= 1.371$ لعشرة أضعاف الخطوات. النتيجة: المعيار ينمو ببطء شديد $\Rightarrow$ «التنظيم الضمني» مستمرّ لكن متضائل. الربط بالذكاء الاصطناعي: في المالية حيث البيانات شبه قابلة للفصل، يكفي التوقّف المبكر وحده تنظيماً.

مثال (34.6-11): هامش مقاس على مجموعة صور المعطيات: هامش متوسّط مقاس 0.05 مع (SGD) و 0.035 مع (Adam) على النموذج نفسه. المطلوب: نسبة الحدّ المعياري بين المُحسِّنين. الحل: الخطوة 1: الحدّ يتناسب عكسياً مع γ إن تساوت المعايير. الخطوة 2: النسبة $\frac{0.05}{0.035} = 1.43$ لصالح (SGD). النتيجة: فارق الهامش يترجم مباشرةً إلى فارق في الحدّ بنسبة الهامشين. الربط بالذكاء الاصطناعي: أحد أسباب تفضيل (SGD) في المرحلة النهائية من تدريب الرؤية.

مثال (34.6-12): (Adam) في النماذج اللغوية الكبيرة المعطيات: تدريب نموذج عميق $L = 32$؛ (SGD) يعطي معياراً إجمالياً 31.7 و (AdamW) بعقوبة 0.1 يعطي 12.4. المطلوب: أثر ذلك على الحدّ المعياري. الحل: الخطوة 1: نسبة المعيار $\frac{31.7}{12.4} = 2.556$. الخطوة 2: لو توزّع الفرق على طبقة واحدة تقلّص الحدّ بعامل 2.556. الخطوة 3: لو توزّع بالتساوي على 32 طبقة لكان العامل $1.0296^{32} = 2.556$ أيضاً (لأنّ 1.0296^{32}): تحقّق $2.556^{1/32} = e^{\ln(2.556)/32} = e^{0.02934} = 1.0298$ ✓. النتيجة: التنظيم الصريح مع (Adam) يعوّض جزءاً كبيراً من ضعف الهامش. الربط بالذكاء الاصطناعي: يفسّر شيوع (AdamW) في تدريب النماذج الكبيرة.

مثال (34.6-13): التوقّف المبكر في تعلّم السياسات المعطيات: هامش السياسة 0.12 عند التوقّف المبكر و 0.31 بعد تدريب كامل، والمعايير متقاربة. المطلوب: أثر التوقّف على الحدّ. الحل: الخطوة 1: الحدّ يتناسب عكسياً مع الهامش $\Rightarrow$ النسبة $\frac{0.31}{0.12} = 2.583$. الخطوة 2: التوقّف المبكر أسوأ هنا بعامل 2.58 في الحدّ (الهامش لم يكتمل). النتيجة: التوقّف المبكر ليس دائماً أفضل: إن أوقفنا قبل اكتمال الهامش دفعنا الثمن. الربط بالذكاء الاصطناعي: القرار يحتاج منحنى تحقّق لا قاعدة ثابتة (الفصل 30).

مثال (34.6-14): التدريب المقاوِم يكبّر الهامش (أمن) المعطيات: هامش مقاس 0.02 قبل التدريب المقاوِم و 0.18 بعده، والمعايير ثابتة تقريباً. المطلوب: أثر ذلك على الحدّ المعياري. الحل: الخطوة 1: النسبة $\frac{0.18}{0.02} = 9 \Rightarrow$ الحدّ يتقلّص تسعة أضعاف. الخطوة 2: لكن الهامش المقاوِم يُقاس بمدى الاضطراب المسموح، فالمقارنة عادلة فقط بالمقياس نفسه. النتيجة: التدريب المقاوِم له قراءة نظريّة مباشرة: تكبير الهامش الفعّال. الربط بالذكاء الاصطناعي: يربط الأمن المقاوِم بنظرية التعميم لا بالتجريب فقط.

مثال (34.6-15): التوقّف المبكر مقابل التنظيم الصريح المعطيات: خياران يصلان إلى المعيار نفسه $\|w\| = 2.0$؛ الأوّل بالتوقّف عند t والثاني بعقوبة λ؛ الخطر التجريبي 0.02 و 0.03 على الترتيب. المطلوب: أيّهما أفضل؟ الحل: الخطوة 1: الحدّ المعياري (34.8) يعتمد على المعيار والهامش: متساويان هنا. الخطوة 2: الخطر التجريبي يختلف: 0.02 مقابل 0.03 لصالح التوقّف المبكر. الخطوة 3: لكنّ التوقّف المبكر يحتاج مراقبةً وبيانات تحقّق، والتنظيم أبسط ضبطاً. النتيجة: لا أفضلية مطلقة: التوقّف المبكر أرخص حسابياً والتنظيم أكثر قابليّة للتكرار. الربط بالذكاء الاصطناعي: اختيارٌ هندسي تُوجّهه النظرية ولا تحسمه.

أخطاء شائعة

- تعميم نتيجة (34.18) على بيانات غير قابلة للفصل (النتيجة مشروطة بالفصل).
- الظنّ أنّ (Adam) «أسوأ» دائماً (انحيازه مختلف لا أضعف، ويتفوّق في مسائل أخرى).
- استخدام «عدد الحقبات» مقياساً للتنظيم بدل حاصل ηt.
- إهمال أنّ الهامش يكبر والمعايير تكبر معاً: التحسين الصافي يحتاج حساب الاثنين.
- الخلط بين التنظيم الصريح (في الهدف) والانحياز الضمني (في المسار).

- افتراض أنّ الانحياز الضمني يحلّ مشكلة المعلمات الزائدة وحده (هو يفسّر جزءاً منها فقط).

المبرهنة (الظاهرة — بيلكين وآخرون 2019، وشرط الاستيعاب الحميد — بارتليت وآخرون 2020، صيغة مبسّطة): ليكن منحنى خطر الاختبار دالّةً في سعة النموذج p مع عيّنة ثابتة الحجم n. يُميَّز ثلاثة أنظمة:

$$\underbrace{p<n}_{\text{تحت مُعلَّم}}:\ p\text{ خطر يهبط مع}\qquad \underbrace{p\approx n}_{\text{نقطة الاستيعاب}}:\ \text{ذروة الخطر}\qquad \underbrace{p>n}_{\text{فوق مُعلَّم}}:\ \text{هبوط ثانٍ} \tag{23.34}$$

ولتكن $\lambda_1\ge\lambda_2\ge\cdots$ طيف مصفوفة التغاير Σ (أو النواة). نعرّف الرتبتين الفعّالتين

$$r_k(\Sigma)\;=\;\frac{\sum_{i>k}\lambda_i}{\lambda_{k+1}},\qquad R_k(\Sigma)\;=\;\frac{\left(\sum_{i>k}\lambda_i\right)^2}{\sum_{i>k}\lambda_i^2} \tag{24.34}$$

فالاستيعاب **حميد** (أي يبقى خطر الاختبار صغيراً مع $\hat R_S=0$) إذا وُجد k يحقّق ثلاثة شروط مقارِبة:

$$\frac{k}{n}\to 0,\qquad r_k(\Sigma)\;\ge\;b\,n\ \ (b>1),\qquad \frac{n}{R_k(\Sigma)}\;\to\;0 \tag{25.34}$$

وخطر الحلّ المستوعِب ذي أصغر معيار يُحصر (بصيغة مبسّطة، الثوابت محذوفة) بـ

$$R(\hat\theta)\;\lesssim\;\underbrace{\|\theta^\star\|^2\,\lambda_{k+1}}_{\text{انحياز}}\;+\;\underbrace{\sigma^2\Big(\frac{k}{n}+\frac{n}{R_k(\Sigma)}\Big)}_{\text{تباين}} \tag{26.34}$$

أمّا الاستيعاب **الخبيث** فيظهر حين ينكسر الشرط الأوسط في (25.34) أو يكبر الضجيج، وعلى وسوم عشوائية يبلغ حدّه الأقصى:

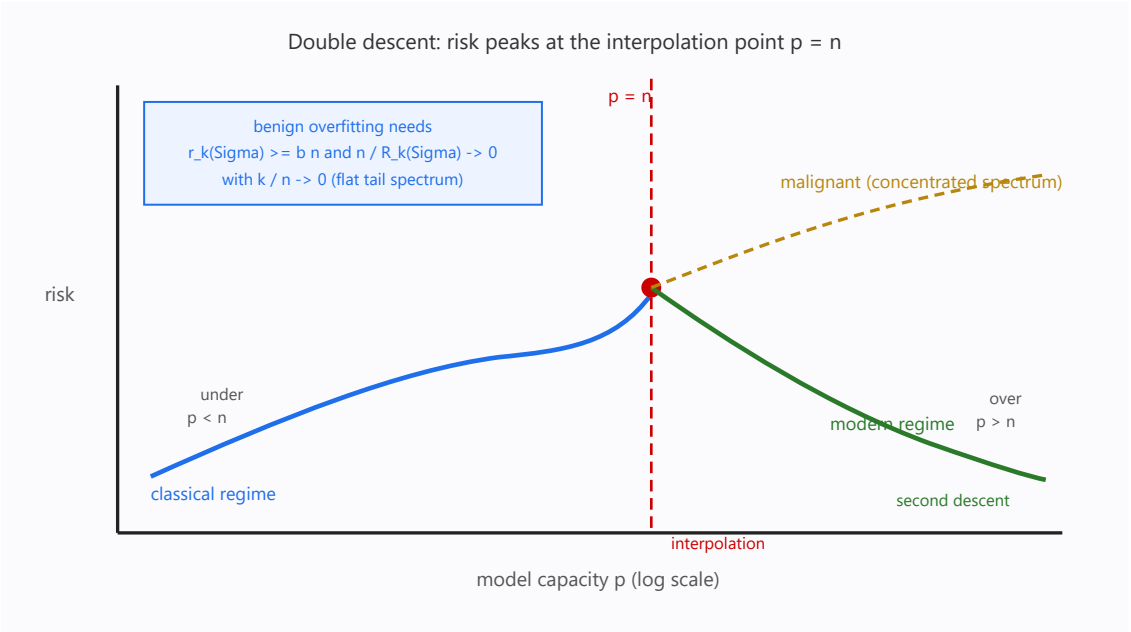
$$\hat R_S(\hat\theta)=0,\qquad R(\hat\theta)\;\longrightarrow\;1-\frac{1}{|\mathcal{Y}|} \tag{27.34}$$

جدول الرموز

الرمز	المعنى	ملاحظة
نقطة الاستيعاب	$p\approx n$	الموضع الذي يصير فيه الحفظ ممكناً
هبوط مزدوج	منحنى الخطر: هبوط ← ذروة ← هبوط	يعكس النظام التجريبي الحديث
استيعاب حميد	$\hat R=0$ مع خطر اختبار صغير	مشروط بالرتبة الفعّالة
استيعاب خبيث	$\hat R=0$ مع خطر اختبار كبير	طيف مركّز أو ضجيج عالٍ
$r_k(\Sigma)$	رتبة فعّالة بالقيمة المفردة الكبرى	يجب أن تكون $\gg n$
$R_k(\Sigma)$	رتبة فعّالة بمجموع المربّعات	يجب أن تكون $\gg n$
σ^2	تباين الضجيج في الوسوم	يضخّم حدّ التباين
λ_{k+1}	أوّل قيمة «ذيلية» في الطيف	تحمل الانحياز

الرسم

<figure> الشكل<figcaption> 6.34: يهبط خطر الاختبار مرّتين: مرّة قبل نقطة الاستيعاب $p\approx n$ حيث تكون النماذج صغيرة، ومرّة بعدها حيث تصير النماذج كبيرة بما يكفي ليكون الحلّ المستوعِب ذا معيار صغير؛ وتظهر الذروة عند نقطة الاستيعاب نفسها.</figcaption> </figure>



شكل ٦.٣٤: *
منحنى الهبوط المزدوج ونقطة الاستيعاب

البرهان

الخطوة 1 (لماذا الذروة عند $p \approx n$؟): عند $p = n$ يكون نظام المعادلات مربّعاً: الحلّ المستوعِب وحيد ومُجبَر على المرور بكلّ نقطة ضجيج، فتُضخَّم مركّبة الضجيج في الاتّجاهات «الضعيفة» (القيم المفردة الصغيرة). ولذلك ينفجر التباين: اضطراب في الوسوم مقداره σ يُضخَّم بعامل يقارب $1/\lambda_{\min}$. وعند $p > n$ تتعدّد الحلول المستوعِبة، فيختار المُحسِّن أصغرها معياراً، فتتوزّع مركّبة الضجيج على أبعاد كثيرة ويهبط التباين ثانيةً. ■

الخطوة 2 (التباين يتحدّد بالرتبة الفعّالة): بتحليل أصغر معيار للمستوعِب في الانحدار الخطّي، يظهر أنّ تباين التقدير يتناسب مع $\frac{n}{R_k(\Sigma)}$ على الذيل الطيفي بعد البعد k: فكلّما كان الذيل **مسطّحاً** (أبعاد كثيرة متساوية القوّة) توزّع الضجيج عليها فصغر أثره، وكلّما كان الذيل مركّزاً في بُعد واحد (قيمة مفردة مسيطرة) تركّز فيه الضجيج فكبر أثره. ■

الخطوة 3 (الشرط الأوسط في (25.34)): لتغطية مركّبة الإشارة في الاتّجاهات الذيلية يجب أن تكون الطاقة الذيلية كبيرة مقارنةً بأكبر قيمة مفردة فيها، أي $r_k(\Sigma) \geq bn$ مع $b > 1$: فإن لم يتحقّق، ضاعت الإشارة في الذيل وبقي الضجيج $\Rightarrow$ استيعاب خبيث. ■

الخطوة 4 (حدّ التباين الكمّي): بجمع حدّ «الأبعاد الأولى» $\sigma^2 \frac{k}{n}$ وحدّ «الذيل» $\sigma^2 \frac{n}{R_k(\Sigma)}$ نحصل على (26.34). الحدّ الأوّل يصغر بكبر n وبصغر k، والثاني يصغر باتّساع الطيف الذيل. ■

الخطوة 5 (منحنى توضيحي): بعيّنة $n = 5 \times 10^4$، يُقرأ المنحنى التوضيحي الآتي (قيم مقترحة لتوضيح الشكل لا قياسات منشورة):

p	10^3	10^4	4×10^4	5×10^4	10^5	10^6	10^7
خطر الاختبار	31.0	24.0	28.0	46.0	26.0	19.0	17.0

فتظهر الذروة عند $p \approx n = 5 \times 10^4$ ثمّ الهبوط الثاني بعدها. ■

الخطوة 6 (الوسوم العشوائية هي الحالة القصوى للخبث): إذا كانت الوسوم مستقلّة عن x تماماً، فلا إشارة أصلاً، وكلّ ما في العيّنة ضجيج؛ فيستوعب النموذج ضجيجاً خالصاً ويبلغ الخطر مستوى الصدفة (27.34): في 10 فئات 0.90.

■

خمسة عشر مثالاً محلولاً

مثال (34.7-1): تحديد نقطة الاستيعاب المعطيات: $n = 5 \times 10^4$ مثال تدريبي، ونغيّر عدد معلمات الشبكة p. المطلوب: أين تقع ذروة الخطر المتوقّعة؟ الحل: الخطوة 1: نقطة الاستيعاب هي الموضع الذي يكفي فيه عدد المعلمات لحلّ نظام بعدد قيود مساوٍ لعدد الأمثلة. الخطوة 2: في التصنيف بـ $|\mathcal{Y}|$ فئة يقابل كلّ مثال قيدٌ واحد، فالذروة عند $p \approx n$. الخطوة 3: إذن الذروة المتوقّعة عند $p \approx 5 \times 10^4$ معلمة. النتيجة: النموذج الأخطر هو الذي «يكاد يكفي» لحفظ العيّنة لا الذي يفيض عنها. الربط بالذكاء الاصطناعي: يفسّر لماذا تُعدّ المنطقة المتوسّطة من السعة هي الأسوأ عملياً.

مثال (34.7-2): قراءة المنحنى التوضيحي المعطيات: المنحنى في الخطوة 5 من البرهان، $n = 5 \times 10^4$. المطلوب: مقدار الارتفاع عند الذروة نسبةً إلى ما قبلها. الحل: الخطوة 1: عند $p = 4 \times 10^4$ الخطر 0.28، وعند $p = 5 \times 10^4$ الخطر 0.46. الخطوة 2: الفرق المطلق $0.46 - 0.28 = 0.18$. الخطوة 3: النسبة $0.46/0.28 = 1.643$ أي تدهور بنحو 64%. النتيجة: الذروة ليست أثراً هامشياً: هي تدهور بنحو الثلثين في الخطر. الربط بالذكاء الاصطناعي: يحذّر من اختيار سعة «وسطى» ظنّاً أنّها أكثر أماناً.

مثال (34.7-3): حساب الرتبة الفعّالة لطيف مركّز المعطيات: $\lambda_1 = 0.9$، و 10^6 قيمة مفردة مقدار كلّ منها 10^{-6}؛ $\mathrm{tr}(\Sigma) = 1.9$. المطلوب: $r_0(\Sigma)$ وتشخيص نوع الاستيعاب مع $n = 10^4$. الحل: الخطوة 1: $r_0 = \frac{\mathrm{tr}(\Sigma)}{\|\Sigma\|_\sigma} = \frac{1.9}{0.9} = 2.111$. الخطوة 2: الشرط الأوسط في (34.25) يتطلّب $r_0 \geq b\,n = 10^4$ تقريباً. الخطوة 3: $2.111 \ll 10^4 \Rightarrow$ الشرط منكسر. النتيجة: استيعاب **خبيث**: الطيف مركّز في بُعد واحد فيتركّز فيه الضجيج. الربط بالذكاء الاصطناعي: البيانات ذات الميزة المسيطرة الواحدة (مثل ميزة مُعَلَّمة بشرياً) هي الأخطر عند الاستيعاب.

مثال (34.7-4): طيف مسطّح يقود إلى استيعاب حميد المعطيات: $\Sigma = I_d$ بـ $d = 10^6$، و $n = 10^4$، و $\sigma^2 = 0.25$. المطلوب: فحص شروط (34.25) وحساب حدّ التباين. الحل: الخطوة 1: $r_0 = \frac{d}{1} = 10^6$ و $R_0 = \frac{d^2}{d} = 10^6$. الخطوة 2: $r_0/n = 100 \geq b$ ✓ و $\frac{n}{R_0} = \frac{10^4}{10^6} = 0.01 \to 0$ ✓ و $\frac{k}{n} = 0 \Rightarrow k = 0$ ✓. الخطوة 3: حدّ التباين $\sigma^2\big(0 + 0.01\big) = 0.25 \times 0.01 = 0.0025$. النتيجة: استيعاب حميد: الخطر محدود بـ 0.0025 زائد حدّ الانحياز. الربط بالذكاء الاصطناعي: يفسّر نجاح النماذج العملاقة على بيانات عالية الأبعاد ذات طيف مسطّح نسبياً.

مثال (34.7-5): الحالة الخبيثة بالأرقام المعطيات: $R_k(\Sigma) = 500$ فقط، $n = 5 \times 10^4$، $k = 100$، $\sigma^2 = 0.25$. المطلوب: حدّ التباين من (34.26). الحل: الخطوة 1: $\frac{k}{n} = \frac{100}{5\times10^4} = 0.002$. الخطوة 2: $\frac{n}{R_k} = \frac{5\times10^4}{500} = 100$. الخطوة 3: التباين $0.25 \times 100.002 = 25.0$. النتيجة: خطر متوقّع يتجاوز كلّ معنى $\Rightarrow$ استيعاب خبيث في أقصى صوره. الربط بالذكاء الاصطناعي: الذيل الطيفي المركّز هو المتهم الأوّل في فشل النماذج المستوعِبة.

مثال (34.7-6): الحالة الحميدة بالأرقام المعطيات: $R_k(\Sigma) = 5 \times 10^5$، $n = 5 \times 10^4$، $k = 100$، $\sigma^2 = 0.25$، $\|\theta^\star\|^2 = 1$، $\lambda_{k+1} = 10^{-3}$. المطلوب: الخطر الكلّي من (34.26). الحل: الخطوة 1: الانحياز $= 0.001 = 1\times10^{-3}$. الخطوة 2: التباين $0.25\times\big(0.002+\frac{5\times10^4}{5\times10^5}\big) = 0.25\times(0.002+0.1) = 0.0255$. الخطوة 3: المجموع $0.0265 = 0.001 + 0.0255$. النتيجة: خطر $2.7\% \approx$ رغم أنّ النموذج يستوعب العيّنة تماماً $(\hat{R} = 0)$. الربط بالذكاء الاصطناعي: هذا هو الاستيعاب الحميد كما صاغه بارتليت وآخرون (2020) بصيغة مبسّطة.

مثال (34.7-7): أثر تباين الضجيج على نوع الاستيعاب المعطيات: الحالة الحميدة في 34.7-6 مع σ^2 من 0.01 إلى 0.5. المطلوب: حدّ التباين في الحالتين ونسبة التضخّم. الحل: الخطوة 1: مع $\sigma^2 = 0.01$: التباين $0.01 \times 0.102 = 0.00102$. الخطوة 2: مع $\sigma^2 = 0.5$: التباين $0.5 \times 0.102 = 0.051$. الخطوة 3:

النسبة $50 = (=$ نسبة التباينين). النتيجة: الاستيعاب الحميد هشّ أمام ضجيج الوسوم: مضاعفة التباين 50 ضعفاً تنقل الخطر من 0.1% إلى 5.1%. الربط بالذكاء الاصطناعي: تنظيف الوسوم أهمّ من تحسين المعمارية في هذه النظم.

مثال (34.7-8): وسوم عشوائية — الحدّ الأقصى للخبث المعطيات: $n = 5 \times 10^4$ صورة بـ 10 فئات ووسوم عشوائية، شبكة $p = 10^7$. المطلوب: خطر الاختبار المتوقّع والفجوة. الحل: الخطوة 1: لا إشارة في البيانات $\Rightarrow$ أيّ «تعلّم» هو حفظ ضجيج. الخطوة 2: خطر الصدفة $1 - \frac{1}{10} = 0.90 =$. الخطوة 3: الفجوة $0.90 - \hat{R} = 0.90 = (\text{لأنّ } \hat{R} = 0)$. النتيجة: (34.27) في أقصى حالاتها: الاستيعاب يستوعب ضجيجاً بنسبة 100%. الربط بالذكاء الاصطناعي: يعود بنا إلى مفارقة 34.2: الحفظ قدرة، ونوع الاستيعاب يحدّده الطيف والضجيج.

مثال (34.7-9): الهبوط المزدوج في تدريب الرؤية المعطيات: شبكة رؤية بعرض متغيّر على $n = 5 \times 10^4$ صورة. المطلوب: التوصية المعمارية في ضوء المنحنى. الحل: الخطوة 1: المنطقة $p \approx 5 \times 10^4$ هي الأسوأ (الذروة 0.46 في المنحنى التوضيحي). الخطوة 2: الانتقال إلى $p = 10^6$ يعطي 0.19 مقابل 0.46 $\Rightarrow$ تحسّن بنسبة 42.2%. الخطوة 3: لا فائدة من التوقّف في المنطقة الوسطى. النتيجة: «كبّر النموذج أو صغّره، ولا تقف في المنتصف» قراءةٌ عملية لمنحنى الهبوط المزدوج. الربط بالذكاء الاصطناعي: يفسّر اتّجاه الممارسة الحديثة نحو النماذج العملاقة.

مثال (34.7-10): النماذج اللغوية بين المعلمات والرموز المعطيات: نموذج $p = 7 \times 10^9$ معلمة مدرَّب على $n = 2 \times 10^{12}$ رمزاً. المطلوب: في أيّ نظام يقع؟ الحل: الخطوة 1: $p/n = 3.5 \times 10^{-3} \Rightarrow n \gg p$. الخطوة 2: إذن النموذج في النظام «تحت المُعلَّم» من حيث عدد الأمثلة. الخطوة 3: لكنّ الرموز ليست أمثلة مستقلّة (النصّ متسلسل)؛ فالحكم يظلّ تقريبيّاً. النتيجة: النماذج اللغوية الكبيرة بعيدة عن نقطة الاستيعاب بالمعنى الكلاسيكي؛ ومع ذلك تظهر ظواهر استيعاب موضعية (حفظ النصوص). الربط بالذكاء الاصطناعي: التكرار في بيانات التدريب يعيد إنتاج ظاهرة الاستيعاب موضعيّاً.

مثال (34.7-11): استيعاب في بيانات طبية صغيرة المعطيات: $n = 1200$ مريض، وشبكة p تتغيّر من 10^3 إلى 10^6. المطلوب: أين نتوقّع الذروة، وما التوصية؟ الحل: الخطوة 1: الذروة عند $p \approx 1200$ معلمة. الخطوة 2: نموذج بـ 10^3 معلمة قريب من الذروة $\Rightarrow$ الأسوأ. الخطوة 3: نموذج بـ 10^6 معلمة في النظام فوق المُعلَّم $\Rightarrow$ أفضل نظريّاً إن صغر معيار الحلّ. النتيجة: في الطبّ، تكبير النموذج مع تنظيم قويّ أنجع من «نموذج صغير مناسب لحجم البيانات». الربط بالذكاء الاصطناعي: يبرّر استخدام نماذج مُدرَّبة مسبقاً وضبطها الدقيق على عيّنات صغيرة.

مثال (34.7-12): سلاسل مالية زمنية المعطيات: $n = 2500$ يوم تداول، ونموذج p من 500 إلى 5×10^5. المطلوب: التشخيص. الحل: الخطوة 1: الذروة عند $p \approx 2500$. الخطوة 2: لكنّ البيانات متسلسلة زمنيّاً فليست i.i.d. (الفصل 30)، فعدد الأمثلة الفعّال أصغر من n. الخطوة 3: بتقدير متحفّظ لحجم العيّنة الفعّال $n_{\text{فعّال}} \approx 500 \Rightarrow$ الذروة تتحرّك إلى $p \approx 500$. النتيجة: نقطة الاستيعاب تعتمد على حجم العيّنة **الفعّال** لا على عدد الصفوف. الربط بالذكاء الاصطناعي: يربط هذا الفصل بالسلاسل الزمنية (الفصل 19) وبمخاطر الاعتماد.

مثال (34.7-13): تعلّم السياسات بعيّنة مختبرية المعطيات: $n = 300$ مسار، وسياسة بمعلمات p من 200 إلى 2×10^5. المطلوب: أين الخطر الأكبر؟ الحل: الخطوة 1: الذروة عند $p \approx 300 \Rightarrow$ وهي منطقة شائعة في سياسات الشبكات الصغيرة. الخطوة 2: التوصية: إمّا سياسة مبنّية صغيرة جدّاً ($p < 100$) أو شبكة كبيرة مع تنظيم قويّ. النتيجة: المنطقة الوسطى هي بالضبط حيث تُضبط كثير من السياسات الافتراضية. الربط بالذكاء الاصطناعي: يفسّر تقلّب نتائج تعلّم التعزيز بين الإعدادات المتقاربة ظاهريّاً.

مثال (34.7-14): كشف شذوذ ببيانات ضخمة (أمن) المعطيات: $n = 10^5$ حدث، نموذج $p = 2 \times 10^5$ معلمة. المطلوب: في أيّ نظام نحن؟ الحل: الخطوة 1: $p/n = 2 \Rightarrow$ في النظام فوق المُعلَّم بقليل. الخطوة 2: الذروة عند

$p = 10^5 \Rightarrow$ نحن بعدها مباشرةً، أي في منحدر الهبوط الثاني. الخطوة 3: التوصية: إمّا العودة إلى $p \ll 10^5$ أو المضيّ إلى $p \geq 10^6$. النتيجة: الموضع الحالي قريب من منطقة غير مستقرّة، والانتقال إلى نموذج أكبر أأمن. الربط بالذكاء الاصطناعي: في الأمن، «الاستقرار» في المنطقة الخطأ من المنحنى يترجم إلى تقلّب في معدّل الإنذار الكاذب.

مثال (15-7.34): متى نتوقّف عن تكبير النموذج؟ المعطيات: المنحنى التوضيحي: $p = 10^6$ يعطي 0.19 و $p = 10^7$ يعطي 0.17. المطلوب: هل يستمرّ التحسّن؟ الحل: الخطوة 1: التحسّن من 10^6 إلى 10^7 مقداره 0.02 فقط مقابل 0.07 من 10^5 إلى 10^6. الخطوة 2: العائد الحدّي يتناقص (بمقدار يقارب $\frac{0.07}{0.02} = 3.5$ ضعفاً في سرعة التحسّن عند السعة الأصغر). الخطوة 3: التكلفة الحسابية تتضاعف عشراً، والتحسّن 0.02. النتيجة: قرار التكبير اقتصاديّ لا نظريّ بعد تجاوز نقطة الاستيعاب بمرتبتين من حيث الحجم. الربط بالذكاء الاصطناعي: النظرية تحدّد الشكل، والموارد تحدّد النقطة.

أخطاء شائعة

- افتراض أنّ منحنى الخطر على شكل U دائماً (في النظام الحديث هو مزدوج الهبوط).
- مطابقة p بعدد المعلمات و n بعدد الأمثلة في بيانات غير مستقلّة (الصحيح: الأحجام الفعّالة).
- توقّع الاستيعاب الحميد في كلّ مسألة (مشروط بطيف مسطّح وضجيج منخفض).
- استخدام الذروة دليلاً على «حجم النموذج الأمثل» (هي أسوأ نقطة لا أفضلها).
- الخلط بين هبوط مزدوج في عدد المعلمات وهبوط مزدوج في عدد الحقبات (ظاهرتان مرتبطتان لا متطابقتان).
- تجاهل أنّ التنظيم قد يمحو الذروة فيحوّل المنحنى إلى شكل U كلاسيكي.

المبرهنة (جاكو، غابرييل، وهونغلر 2018؛ وأرورا وآخرون 2019): لتكن $f(x;\theta)$ شبكةً بعرض m لكلّ طبقة مخفيّة ومعلمات θ. نعرّف نواة التماس العصبية بـ

$$\Theta(x, x') \;=\; \big\langle \nabla_\theta f(x;\theta),\, \nabla_\theta f(x';\theta) \big\rangle \tag{28.34}$$

فعند $m \to \infty$ (بتهيئة مناسبة) تتقارب Θ إلى نواة **ثابتة** Θ_∞ لا تعتمد على التهيئة العشوائية ولا تتغيّر أثناء التدريب. وفي هذا النظام تصير ديناميكا التدريب بالزمن المستمرّ:

$$\frac{d\theta}{dt} \;=\; -\nabla_\theta L, \qquad \frac{df_t}{dt} \;=\; -\nabla_\theta f^{\top}\,\frac{d\theta}{dt} \;=\; -\Theta\,(f_t - y) \tag{29.34}$$

أي انحدارٌ خطّي بنواة ثابتة، بحلٍّ مغلق:

$$f_t - y \;=\; e^{-\Theta\, t}\,(f_0 - y), \qquad t_\varepsilon \;\approx\; \frac{\ln(1/\varepsilon)}{\lambda_{\min}(\Theta)} \tag{30.34}$$

ويتحقّق نظام «التدريب الكسول» (lazy training) — أي بقاء النواة ثابتة فعلاً — إذا بقيت المعلمات قريبة من تهيئتها:

$$\frac{\|\theta_t - \theta_0\|}{\|\theta_0\|} = O\!\left(\frac{1}{\sqrt{m}}\right) \ll 1 \tag{31.34}$$

وفي هذا النظام يُحصر خطر التعميم (أرورا وآخرون) بـ

$$R \le \tilde{O}\!\left(\sqrt{\frac{2\, y^{\top}\Theta^{-1} y}{n}}\right) \tag{32.34}$$

ويتطلّب التكامل العددي المستقرّ حجم خطوة محكوماً بأكبر قيمة ذاتية للنواة:

$$\eta \le \frac{2}{\lambda_{\max}(\Theta)} \tag{33.34}$$

جدول الرموز

الرمز	المعنى	ملاحظة
Θ	نواة التماس العصبية	على العيّنة $n \times n$
m	عرض الطبقة المخفيّة	نظام النواة $m \to \infty$
f_t	مُخرجات الشبكة على العيّنة عند الزمن t	متّجه بطول n
$e^{-\Theta t}$	أُسّ المصفوفة	تقاربٌ بمعدّل القيم الذاتية
$\lambda_{\min}, \lambda_{\max}$	أصغر وأكبر قيمة ذاتية لـ Θ	تحكّمان بالسرعة والاستقرار
تدريب كسول	النواة ثابتة، المعلمات لا تتحرّك كثيراً	انحدار نواة خالص
تعلّم التمثيل	النواة تتغيّر مع التدريب	ما يميّز الشبكات الحقيقية
$y^{\top}\Theta^{-1}y$	تعقيد النواة	أصغر ما يكون مع نواة «واسعة الطيف»

الرسم

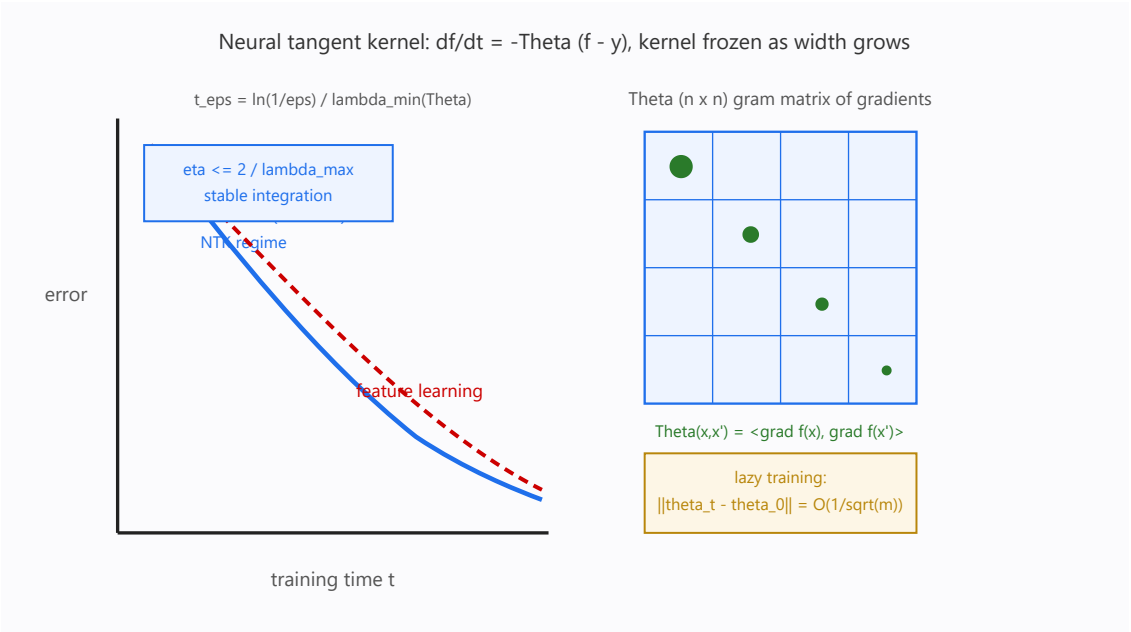
<figure> الشكل<figcaption> 7.34: في نظام العرض اللانهائي يهبط خطأ التدريب أُسّيّاً بمعدّل القيم الذاتية لنواة التماس، وتصير الشبكة انحداراً بنواة ثابتة؛ أمّا الشبكات الفعلية فتتعلّم تمثيلاً وتتغيّر نواتها مع التدريب.</figcaption> </figure>

البرهان

الخطوة 1 (حساب النواة): f دالّة في θ، فبقاعدة السلسلة: $\frac{df(x)}{dt} = \langle \nabla_\theta f(x), \frac{d\theta}{dt} \rangle$. وبالتعريف (29.34) للهبوط بالتدرّج على خسارة تربيعية $L = \frac{1}{2}\|f - y\|^2$: $\nabla_\theta L = \nabla_\theta f^{\top}(f - y)$؛ فنحصل على $\frac{df_t}{dt} = -\Theta(f_t - y)$ حيث Θ مصفوفةُ الجِرام لتدرّجات المُخرجات، وهو (28.34). ■

الخطوة 2 (ثبات النواة في العرض اللانهائي): كلّ مدخل في Θ مجموعٌ من m حدود شبه مستقلّة، فيتّجه تركيزه حول قيمته المتوقّعة بسرعة $O(1/\sqrt{m})$ (متراجحات التركيز، الفصل 17). وحركة المعلمات خلال التدريب من رتبة $O(1/\sqrt{m})$ أيضاً في التهيئة المناسبة، فتبقى Θ ثابتة على مدى التدريب كلّه $\Rightarrow$ (31.34). ■

الخطوة 3 (الحلّ المغلق): المعادلة (29.34) خطّية ذات معاملات ثابتة في نظام النواة، وحلّها $f_t - y = e^{-\Theta t}(f_0 - y)$. بتحليل Θ إلى قيم ذاتية، تهبط كلّ مركّبة بعامل $e^{-\lambda_i t}$؛ فزمن الهبوط إلى ε محكوم بأصغر قيمة ذاتية $\Rightarrow$ (30.34). ■



شكل ٧.٣٤: *
ديناميكا نواة التماس العصبية ونظام التدريب الكسول

الخطوة 4 (الاستقرار العددي): تكامل أويلر للمعادلة (29.34) مستقرّ إذا كان $\eta\lambda_{\max} \le 2$ $\Rightarrow$ (33.34). وهذا يربط بين «عرض الشبكة» و«حجم الخطوة المسموح»: ففي التهيئة التي تجعل Θ مستقلّة عن m يبقى η مستقلّاً عن m أيضاً، أمّا في التهيئات الأخرى فيتغيّر المقياس مع العرض. ■

الخطوة 5 (حدّ التعميم): في نظام النواة الثابتة تصير المسألة انحدارَ نواة (kernel ridge/gradient flow)؛ وخطر التعميم محكوم بمقدار $\frac{y^\top \Theta^{-1} y}{n}$ الذي يقيس «مدى ملاءمة النواة لوسوم العيّنة»: فالنواة التي تجعل y «قصيراً» في مقياسها (أي يسهل تمثيل الوسوم بها) تعطي حدّاً أضيق $\Rightarrow$ (32.34). ■

الخطوة 6 (حدود النظام): الشروط تتطلّب m كبيراً جدّاً مقارنةً بـ n (عديد حدود في n)؛ والشبكات الحقيقية تعمل بعرض أصغر من ذلك بكثير، فنواتها **تتغيّر** أثناء التدريب (feature learning) وتتعلّم تمثيلاً — وهو ما يفسّر تفوّقها التجريبي على انحدار النواة في المسائل الصعبة. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.34): حساب نواة شبكة ثنائية الطبقات (ReLU) المعطيات: نواة القوس-جيب: $\Theta(x,x') = \frac{\|x\|\|x'\|}{2\pi}\big((\pi - \arccos\rho)\rho + \sqrt{1-\rho^2}\big)$ مع $\rho = \cos\angle(x,x')$، و $\|\cdot\| = 1$. المطلوب: قيم النواة عند $\rho = 1$ و $\rho = 0.5$ و $\rho = 0$. الحل: الخطوة 1: $\rho = 1 \Rightarrow \arccos 1 = 0$، $\Theta = \frac{1}{2\pi}(\pi \times 1 + 0) = \frac{\pi}{2\pi} = 0.5$. الخطوة 2: $\rho = 0.5$: $(\pi - 1.0472)\times 0.5 + \sqrt{0.75} = 1.0472 + 0.8660 = 1.9132 \Rightarrow \arccos 0.5 = 1.0472$، $\Rightarrow \frac{1.9132}{6.2832} = 0.3045 \Rightarrow 0 + \sqrt{1} = 1 \Rightarrow \arccos 0 = 1.5708$:$\rho = 0$ الخطوة 3: $\Theta = \frac{1}{6.2832} = 0.1592$. النتيجة: النواة موجبة دائماً وتنخفض مع تباعد المتّجهين: مقياسُ تشابهٍ تعليمي. الربط بالذكاء الاصطناعي: هذه النواة هي ما يُحسب فعلاً في تطبيقات انحدار النواة العصبية اللانهائي.

مثال (2-8.34): زمن التقارب في نظام النواة المعطيات: $\lambda_{\min}(\Theta) = 0.01$، ومطلوب الوصول إلى خطأ نسبي $\varepsilon = 0.01$، وحجم خطوة $\eta = 0.1$. المطلوب: الزمن المستمرّ وعدد الخطوات. الحل: الخطوة 1: $t_\varepsilon = \frac{\ln(1/0.01)}{0.01} = \frac{4.6052}{0.01} = 460.5$ وحدة زمنية. الخطوة 2: عدد الخطوات $= \frac{t}{\eta} = \frac{460.5}{0.1} = 4605$

خطوة. الخطوة 3: لو ضاعفنا $\lambda_{\min}$ إلى 0.02 لصار العدد 2303 خطوة. النتيجة: التقارب أُسّيّ وزمنه يتناسب عكسيّاً مع أصغر قيمة ذاتية. الربط بالذكاء الاصطناعي: يفسّر «البطء المفرط» لاتّجاهات النواة الضعيفة في التدريب العملي.

مثال (34.8-3): حجم الخطوة المسموح المعطيات: $\lambda_{\max}(\Theta) = 200$. المطلوب: أكبر حجم خطوة مستقرّ. الحل: الخطوة 1: الشرط (34.33): $\eta \le \frac{2}{\lambda_{\max}}$. الخطوة 2: $\eta \le \frac{2}{200} = 0.01$. الخطوة 3: عند $\eta = 0.02$ يصير التكامل على الحافّة، وعند 0.05 يتباعد. النتيجة: مقياس حجم الخطوة مرتبطٌ بطيف النواة لا بعدد المعلمات. الربط بالذكاء الاصطناعي: يبرّر البحث عن طيف النواة عمليّاً لضبط معدّل التعلّم.

مثال (34.8-4): حدّ تعميم النواة غير الفارغ المعطيات: وسوم $y \in \{\pm 1\}^n$ بـ $\|y\|^2 = n$، و $\lambda_{\min}(\Theta) = 50$ مقاسة، و $n = 5 \times 10^4$. المطلوب: الحدّ من (34.32). الحل: الخطوة 1: $\frac{\|y\|^2}{\lambda_{\min}} = \frac{n}{50}$. الخطوة 2: $y^\top \Theta^{-1} y \le \frac{2y^\top \Theta^{-1} y}{n} \le \frac{2}{50} = 0.04$. الخطوة 3: الحدّ $\sqrt{0.04} = 0.2$. النتيجة: حدّ غير فارغ على شبكة واسعة: هذا من أهمّ نجاحات برنامج النواة العصبية. الربط بالذكاء الاصطناعي: يجعل من «طيف النواة» هدفاً قابلاً للقياس في هندسة النماذج.

مثال (34.8-5): هل نحن في النظام الكسول؟ المعطيات: نسبة تغيّر النواة $\frac{\|\Theta_t - \Theta_0\|_F}{\|\Theta_0\|_F}$ مقاسة: 0.03 في تجربة و 0.45 في أخرى. المطلوب: التشخيص. الحل: الخطوة 1: التغيّر 3% $\Rightarrow$ النواة شبه ثابتة $\Rightarrow$ انحدار نواة $\Rightarrow$ النظام الكسول. الخطوة 2: التغيّر 45% $\Rightarrow$ النواة تتحرّك جوهريّاً $\Rightarrow$ تعلّم تمثيل. الخطوة 3: الحدّ (34.32) يصلح للحالة الأولى فقط. النتيجة: القياس المباشر لتغيّر النواة هو الفاصل العملي بين النظامين. الربط بالذكاء الاصطناعي: الشبكات الحقيقية تقع بينهما، ولذلك تُستخدم النواة معياراً مرجعيّاً لا نموذجاً نهائيّاً.

مثال (34.8-6): هل يكفي العرض في الممارسة؟ المعطيات: $n = 5 \times 10^4$ مثال، وعرض الطبقة $m = 512$. المطلوب: هل نحن في نظام (NTK) الصارم؟ الحل: الخطوة 1: النظام الصارم يتطلّب عرضاً يفوق n بعدّة مراتب (عديد حدود في n). الخطوة 2: $\frac{m}{n} = \frac{512}{5\times 10^4} = 0.01024 \Rightarrow$ العرض أصغر من العيّنة بـ 98 ضعفاً. الخطوة 3: إذن $\frac{1}{\sqrt{m}} = \frac{1}{22.6} = 0.0442$ ليس صغيراً بما يكفي لضمان ثبات النواة. النتيجة: الشبكات العملية **ليست** في نظام (NTK) الصارم، بل في نظام وسيط. الربط بالذكاء الاصطناعي: يفسّر الفجوة بين تنبّؤات النواة وسلوك الشبكات الحقيقية.

مثال (34.8-7): حدّ النواة على مسألة رؤية المعطيات: $n = 10^4$، $\lambda_{\min}(\Theta) = 0.5$ مقاسة. المطلوب: الحدّ من (34.32). الحل: الخطوة 1: $y^\top \Theta^{-1} y \le \frac{10^4}{0.5} = 2 \times 10^4$. الخطوة 2: $\frac{2\times 2\times 10^4}{10^4} = 4$. الخطوة 3: الحدّ $\sqrt{4} = 2 \Rightarrow$ فارغ. النتيجة: نواة بقيمة ذاتية صغرى ضعيفة تعطي حدّاً فارغاً: الطيف هو كلّ شيء. الربط بالذكاء الاصطناعي: يحفّز تصميم معماريات/تهيئات تُحسّن طيف النواة.

مثال (34.8-8): حدّ النواة على مسألة لغوية المعطيات: $n = 5 \times 10^4$، $\lambda_{\min}(\Theta) = 20$. المطلوب: الحدّ. الحل: الخطوة 1: $y^\top \Theta^{-1} y \le \frac{5\times 10^4}{20} = 2500$. الخطوة 2: $\frac{2\times 2500}{5\times 10^4} = 0.1$. الخطوة 3: الحدّ $\sqrt{0.1} = 0.3162$. النتيجة: حدّ ذو معنى: تحسين الطيف من 0.5 إلى 20 نقل الحدّ من 2 إلى 0.316. الربط بالذكاء الاصطناعي: يبرّر دراسة «طيف التماس» بوصفه أداة تشخيص معمارية.

مثال (34.8-9): تطبيق طبي بعيّنة صغيرة المعطيات: $n = 2000$، $\lambda_{\min}(\Theta) = 5$. المطلوب: الحدّ. الحل: الخطوة 1: $\frac{2y^\top \Theta^{-1} y}{n} \le \frac{2}{5} = 0.4$. الخطوة 2: الحدّ $\sqrt{0.4} = 0.6325$. النتيجة: حدّ فضفاض لكن غير فارغ؛ العيّنة الصغيرة تحدّ من الفائدة. الربط بالذكاء الاصطناعي: في الطبّ، الشبكة الواسعة تعطي ضماناً ضعيفاً؛ البيانات أنجع.

مثال (34.8-10): تسعير مالي بنواة عصبية المعطيات: $n = 10^4$، $\lambda_{\min}(\Theta) = 200$. المطلوب: الحدّ. الحل: الخطوة 1: $\frac{2y^\top \Theta^{-1} y}{n} \le \frac{2}{200} = 0.01$. الخطوة 2: الحدّ $\sqrt{0.01} = 0.1$. النتيجة: حدّ قويّ: طيف واسع وبيانات كافية. الربط بالذكاء الاصطناعي: النواة العصبية بديلٌ قابل للتحليل في المسائل المالية منخفضة الأبعاد.

مثال (34.8-11): تعلّم سياسة روبوتية المعطيات: $n = 500$، $\lambda_{\min}(\Theta) = 0.5$. المطلوب: الحدّ والتوصية. الحل:

الخطوة 1: $4 = \frac{2}{0.5} \leq \frac{2y^\top \Theta^{-1} y}{n} \Rightarrow$ الحدّ $= 2 \Rightarrow$ فارغ. الخطوة 2: السبب: العيّنة صغيرة جدّاً ولا تعوّضها قوّة الطيف. النتيجة: في الروبوتات تبقى النواة أداة تحليل لا أداة ضمان. الربط بالذكاء الاصطناعي: يعزّز الاعتماد على التقييم التجريبي المباشر للسياسات.

مثال (12-8.34): كشف اختراق بنواة عصبية المعطيات: $n = 10^5$، $\lambda_{\min}(\Theta) = 100$. المطلوب: الحدّ. الحل: الخطوة 1: $\frac{2}{100} = 0.02 \Rightarrow$ الحدّ $= \sqrt{0.02} = 0.1414$. النتيجة: حدّ مفيد: البيانات الضخمة والطيف الجيّد يعطيان ضماناً قابلاً للاستخدام. الربط بالذكاء الاصطناعي: النظم الأمنية من أفضل مرشّحات تطبيق حدود النواة.

مثال (13-8.34): النماذج اللغوية العملاقة ليست كسولة المعطيات: نسبة تغيّر النواة مقاسة 0.45 في نموذج عميق مدرَّب على نصوص. المطلوب: التشخيص النظري. الحل: الخطوة 1: التغيّر $45\% \Rightarrow$ خارج نظام (NTK) الثابت. الخطوة 2: إذن حدّ (32.34) لا ينطبق، والحدود المعيارية (6.34) أولى بالاعتبار. الخطوة 3: والقراءة: النموذج يتعلّم تمثيلاً (feature learning) لا مجرّد انحدار نواة. النتيجة: تفوّق النماذج الكبيرة على انحدار النواة دليلٌ على تعلّم التمثيل لا على بطلان .(NTK) الربط بالذكاء الاصطناعي: (NTK) معيارٌ مرجعيّ يبيّن **ماذا** تضيف ديناميكا التمثيل.

مثال (14-8.34): أثر العرض على ثبات النواة المعطيات: تقلب النواة عند التهيئة يتناسب مع $\frac{1}{\sqrt{m}}$؛ نقارن $m = 100$ و $m = 10^4$. المطلوب: نسبة التقلب. الحل: الخطوة 1: $m = 100 : 0.1 = \frac{1}{10} \Rightarrow$ تقلب 10%. الخطوة 2: $m = 10^4 : 0.01 = \frac{1}{100} \Rightarrow$ تقلب 1%. الخطوة 3: النسبة $= \frac{0.1}{0.01} = 10$ (= $\sqrt{100}$). النتيجة: مضاعفة العرض 100 ضعفاً تقلّص تقلب النواة 10 أضعاف فقط (جذر). الربط بالذكاء الاصطناعي: يفسّر بطء دخول الشبكات الحقيقية في نظام النواة: العرض يجب أن يكون هائلاً.

مثال (15-8.34): قراءة شاملة — ماذا نربح من (NTK) وماذا نخسر؟ المعطيات: حدّ (32.34) غير فارغ (0.2 في 4-8.34) لكنّ الشبكات الحقيقية تتفوّق على انحدار النواة. المطلوب: التفسير. الحل: الخطوة 1: نربح: ديناميكا قابلة للحلّ المغلق، وحدّ تعميم قابل للحساب، وضبط لحجم الخطوة. الخطوة 2: نخسر: تعلّم التمثيل — وهو مصدر القوّة التجريبية الأكبر للشبكات العميقة. الخطوة 3: إذن (NTK) يفسّر **التقارب** ولا يفسّر **التمثيل**. النتيجة: نظام (NTK) هو «الحالة المنحلة» التي تُقاس عليها الشبكات، لا النموذج النهائي لها. الربط بالذكاء الاصطناعي: يمهّد للجزء السابع: بنية الشبكة نفسها بوصفها كائناً رياضيّاً قابلاً للتحليل.

أخطاء شائعة

- تطبيق حدود (NTK) على شبكة بعرض صغير أو بمعدّل تعلّم كبير (النواة حينئذٍ تتغيّر).
- الخلط بين نواة التهيئة Θ_0 ونواة أثناء التدريب Θ_t.
- افتراض أنّ $f_0 = 0$ دائماً (في التهيئة القياسية نعم، لكنّ بقايا الوصلات قد تغيّر ذلك).
- استخدام $\lambda_{\min}$ مقيساً على دفعة صغيرة ثمّ تعميمه على العيّنة كلّها.
- الظنّ أنّ انحدار النواة يعادل الشبكة في الأداء (الشبكة تتفوّق بتعلّم التمثيل).
- نسيان شرط التهيئة: ثبات النواة مشروط بمقياس التهيئة المناسب (انظر 14-8.34).

ملخّص النظريات

النظرية	المفهوم المحوري	الحدّ	هل هو غير فارغ؟
2.34 مفارقة المعلمات الزائدة	الحفظ بلا تعلّم	$\sqrt{16\ln 2+\frac{8}{n}\ln\frac{4}{\delta}}\approx 3.33$	لا — فارغ دائماً
3.34 حدود معيارية	المعيار الطيفي والهامش	$\tilde{O}(\frac{\|X\|_F\prod\|W_l\|_\sigma}{\gamma\sqrt{n}}L^{3/2})$	نادراً — قيمته في الاتجاه
4.34 حدود (PAC-Bayes)	تباعد (KL) بين البعدي والقبلي	$\sqrt{\frac{\mathrm{KL}+\ln(2n/\delta)}{2n}}$	نعم — عند (KL) معقول
5.34 حدود الضغط	طول الوصف k و b	$\tilde{O}(\sqrt{\frac{k\ln n}{n}})+\gamma$	نعم — عند ضغط جذري
6.34 الانحياز الضمني	أقصى هامش دون عقوبة	$\|w_t\|=\Theta(\log t)$	يفسّر لا يحدّ
7.34 الهبوط المزدوج	ثلاثة أنظمة وطيف Σ	$\frac{n}{R_k}\to 0$ و $r_k\geq bn$	يفسّر المنحنى
8.34 نواة التماس (NTK)	انحدار بنواة ثابتة	$\tilde{O}(\sqrt{\frac{2y^\top\Theta^{-1}y}{n}})$	نعم — في النظام الكسول

القاعدة الجامعة: كلّما انتقلنا من «سعة الفضاء» إلى «سعة الحلّ المحقَّق» — معاييره، أو توزيعه البعدي، أو طول وصفه، أو مسار مُحسِّنه، أو نواته — ضاق الحدّ واقترب من الواقع.

عشرون تمريناً (مع إجابات مختصرة)

١. ما معنى أن يكون الحدّ «فارغاً»؟ (أن يتجاوز أقصى خطر ممكن، أي 1 لخسارة في $[0,1]$)

٢. متى تساوي دالّة النموّ 2^m؟ (عند $m\leq d_{VC}$)

٣. لماذا لا يتحسّن حدّ بُعد VC بزيادة n في الشبكات العميقة؟ (لأنّ المقدار المهيمن $16\ln 2$ مستقلّ عن n)

٤. كم بتّاً يلزم لحفظ n وسماً ثنائيّاً؟ (n بتّاً)

٥. ما المتغيّر الذي يحلّ محلّ عدد المعلمات في الحدّ المعياري؟ ($\prod_l\|W_l\|_\sigma$ و γ و $L^{3/2}$)

٦. لماذا يفيد التطبيع الطيفي نظريّاً؟ (يصغّر $\prod\|W_l\|_\sigma$ فيبقى p كما هو)

٧. ما الفرق بين kl و KL؟ (الأولى لبرنوليّتين والثانية عامّة؛ الأولى أصغر فتعطي حدّاً أضيق)

٨. ما (KL) بين غاوسيّين متّحدي التباين بمركزين w و 0؟ ($\frac{\|w\|^2}{2\sigma^2}$)

٩. ما شرط صحّة حدّ (PAC-Bayes) على القبلي؟ (أن يكون مستقلّاً عن العيّنة)

١٠. ماذا يقيس k في حدود الضغط؟ (عدد معلمات الوصف المضغوط لا عدد معلمات الشبكة)

١١. بكم يتقلّص حدّ الضغط عند التكميم من 32 بتّاً إلى 4؟ (بعامل $\sqrt{8}=2.83$)

١٢. إلى أيّ حلّ يخو هبوط التدرّج على بيانات قابلة للفصل؟ (إلى حلّ أقصى هامش بلا عقوبة صريحة)

١٣. كيف ينمو معيار الحلّ مع عدد الخطوات؟ ($\|w_t\|=\Theta(\log t)$)

١٤. ما الانحياز الضمني التقريبي لـ (Adam)؟ (نحو هامش ℓ_∞ أقصى بدل ℓ_2)

١٥. ما التكافؤ الإرشادي للتوقّف المبكر؟ ($\lambda\approx\frac{2}{\eta t}$)

١٦. أين تقع ذروة منحنى الهبوط المزدوج؟ (عند $p\approx n$)

١٧. ما شرط الاستيعاب الحميد بالرتبة الفعّالة؟ ($r_k(\Sigma) \geq bn$ و $\frac{k}{n} \to 0$ و $\frac{n}{R_k} \to 0$)

١٨. ماذا يحدث عند وسوم عشوائية في 10 فئات؟ ($\hat{R} = 0$ و $R \to 0.90$)

١٩. ما نواة التماس العصبية؟ ($\Theta(x, x') = \langle \nabla_\theta f(x), \nabla_\theta f(x') \rangle$)

٢٠. متى تصير الشبكة انحداراً بنواة ثابتة؟ (في نظام التدريب الكسول حيث $\frac{\|\theta_t - \theta_0\|}{\|\theta_0\|} = O(1/\sqrt{m})$)

فهرس الرموز

الرمز	المعنى
n, p, L, m	حجم العيّنة، عدد المعلمات، العمق، العرض
W_l, $\|W_l\|_\sigma$, $\|X\|_F$	الأوزان، المعيار الطيفي، معيار فروبنيوس للمدخلات
γ, $\bar{\gamma}$	الهامش والهامش المعيّر
$\Pi_{\mathcal{H}}$, d_{VC}, $\hat{\mathfrak{R}}_n$	دالّة النموّ، البعد، تعقيد Rademacher
P, Q, KL, kl	القبلي، البعدي، التباعدان
k, b, $\gamma_{\text{ضغط}}$	معلمات الوصف، البتّات، خطأ الضغط
r_k, R_k, Σ, σ^2	الرتب الفعّالة، التغاير، تباين الضجيج
Θ, $\lambda_{\min}$, $\lambda_{\max}$, η	النواة، طيفها، حجم الخطوة
w_t, γ_t, θ_t	مسار المعلمات والهامش أثناء التدريب

مراجع

- Vinyals & Recht Hardt, Bengio, Zhang, «Understanding — Deep Learning Requires Rethinking Generalization» (ICLR 2017)؛ ونسخة (CACM 2021).
- Vinyals & Recht Hardt, Bengio, Zhang, «Understanding — Deep Learning Requires Rethinking Generalization» (Communications of the ACM، 2021).
- Telgarsky & Foster Bartlett, «Spectrally-Normalized — Margin Bounds for Neural Networks» (NeurIPS 2017).
- Tsigler & Lugosi Long, Bartlett, «Benign — Linear Regression in Overfitting» (PNAS، 2020).
- Mehrabian & Liaw Harvey, Bartlett, «Nearly-Tight — VC-Dimension and Pseudodimension Bounds for Piecewise Linear Neural Networks» (JMLR، 2019).
- McAllester «PAC-Bayesian — Model Averaging» و «Some PAC-Bayesian Theorems» (COLT، 1999).
- Maurer «A — Note on the PAC Bayesian Theorem» (COLT، 2004).
- Roy & Dziugaite «Computing — Nonvacuous Generalization Bounds for Deep (Stochastic) Neural Networks» (UAI/ICML، 2017).
- Zhang & Neyshabur Ge, Arora, «Stronger — Generalization Bounds for Deep Nets via a Compression Approach» (ICLR، 2018).
- Li, Hu, Du, Arora, Wang & Salakhutdinov «On — Exact Computation with an Infinitely Wide Neural Net» (NeurIPS، 2019).
- Jacot, Gabriel & Hongler «Neural — Tangent Kernel: Convergence and Generalization in Neural Networks» (NeurIPS، 2018).

- Hsu, Belkin, & Ma — «Reconciling Modern Machine-Learning Practice and the Classical Bias–Variance Trade-Off» (PNAS، 2019).
- Belkin, Hsu, Ma & Mandal — «Reconciling Modern Machine-Learning Practice and the Bias-Variance Trade-Off» (ICML، 2018).
- Nakkiran, Kaplun, Bansal, Yang, Barak & Sutskever — «Deep Double Descent: Where Bigger Models and More Data Hurt» (ICLR، 2020).
- Nacson, Hoffer, Soudry, Gunasekar & Srebro — «The Implicit Bias of Gradient Descent on Separable Data» (JMLR، 2018).
- Gunasekar, Woodworth, Bhojanapalli, Neyshabur & Srebro — «Implicit Regularization in Matrix Factorization» (NeurIPS، 2017).
- Gunasekar, Lee, Soudry & Srebro — «Implicit Bias of Gradient Descent on Linear Convolutional Networks» (NeurIPS، 2018).
- Neyshabur, Bhojanapalli, McAllester & Srebro — «Exploring Generalization in Deep Learning» (NeurIPS، 2017).
- Ben-David & Shalev-Shwartz — *Understanding Machine Learning* (الإطار الذي تُقاس عليه هذه الحدود).

خاتمة الجزء السادس — نظرية التعلّم الإحصائي: بدأنا هذا الجزء بسؤال واحد: متى يعمّم ما تعلّمناه؟ فأجبنا على مستويات متزايدة الدقّة: إطار الخطر و (ERM) و (SRM) والتحيز–التباين (الفصل 30)، ثمّ مقاييس السعة بُعد VC و Rademacher (الفصل 31)، ثمّ ضمانات (PAC) (الفصل 32)، ثمّ الاستقرار الخوارزمي (الفصل 33)، وختمنا هنا (الفصل 34) بمواجهة النظرية مع الشبكات العميقة: لماذا تصير الحدود الكلاسيكية فارغة، وما البدائل التي تبقى غير فارغة — المعايير، و (PAC-Bayes)، والضغط، والانحياز الضمني، والاستيعاب الحميد، ونواة التماس.

<

وما بقي معلّقاً هو سؤالٌ من نوع آخر: لقد تعاملنا مع الشبكة «صندوقاً» يختار فرضية من فضاء. لكنّ للشبكة بنيةً — خلايا، وطبقات، ودوالّ تنشيط، واتّصالات — وتلك البنية نفسها كائنٌ رياضيّ يستحقّ التحليل المستقلّ: متى تكون الشبكة قادرة على تمثيل أيّ دالّة؟ وكم خلية يلزمها؟ ولماذا يعمل الانتشار العكسي أصلاً؟

<

الجزء السابع — رياضيات الشبكات العصبية — يبدأ من هنا، ويستهلّه **الفصل 35: البيرسيبترون والشبكات الأمامية ونظريات التقريب الشامل**: من الخلية المفردة وخوارزمية إقلاعها، إلى الشبكة الأمامية بوصفها مؤلّفةً دوالّ، إلى مبرهنات التقريب الشامل التي تجيب عن السؤال الأوّل: هل تستطيع الشبكة — من حيث المبدأ — أن تمثّل ما نريد؟

القسم VII

رياضيات الشبكات العصبية

نبذة عن هذا الجزء

حان وقت البطل: الشبكات العصبية نفسها. لكننا لن نقدّمها كوصفات هندسية، بل كرياضياتٍ خالصة. نبدأ من **البيرسيبترون والشبكات الأمامية** ونظرية التقريب الشامل: لماذا تكفي الشبكات عملاً بكلّ دالّة معقولة؟ ثم **الانتشار العكسي والتفاضل التلقائي** حيث يتحوّل قاعدة السلسلة إلى خوارزميةٍ تُنفَّذ بمكوّنين فقط، **فالشبكات الالتفافيّة** وجبرها المرن مع الأبعاد المكانية، و**المتكرّرات** وجبر التفكّ عبر الزمن ومشكلة التدرّجات المتباعدة. ثم ثورة **المحوّلات**: الانتباه الذاتي صيغةً مصفوفية وتكلفته التربيعية وخدعه الزمنية. بعدها نظرة الأعماق: **نواة النهاية اللانهائية NTK** التي تشرح ماذا تتعلم الشبكة شبه العريضة فعلاً، ثم **النماذج التوليدية** — VAE وGAN وFlows وDffiusion — كلها بلغة السكور والنقل، ونختم بـ**النقل الأمول**: واسرشتاين، وكانتوروفيتش، وسينكورن، وأثرها في WGAN وحسابات المسافات بين التوزيعات. **فصول الجزء:** البيرسيبترون والشبكات الأمامية · الانتشار العكسي والتفاضل التلقائي · الشبكات الالتفافية · الشبكات المتكرّرة · المحوّلات والانتباه · نواة النهاية اللانهائية · النماذج التوليدية · النقل الأمول.

فصول هذا الجزء

- **الفصل 35.** البيرسيبترون، الشبكات الأمامية، ونظريات التقريب الشامل
- **الفصل 36.** الانتشار العكسي بوصفه تفاضلاً آلياً عكسياً
- **الفصل 37.** الشبكات الالتفافية: الالتفاف، الطوبولوجيا، والتماثل
- **الفصل 38.** الشبكات المتكرّرة ورياضيات الزمن
- **الفصل 39.** المحوّلات: الانتباه، الترميز الموضعيّ، والتعقيد
- **الفصل 40.** نواة التماس العصبية (Neural Tangent Kernel)
- **الفصل 41.** النماذج التوليدية (Generative Models)
- **الفصل 42.** النقل الأمثل والمسافات المائية (Optimal Transport & Wasserstein)

البيرسيبترون، الشبكات الأمامية، ونظريات التقريب الشامل

«وحدةٌ بسيطةٌ متّصلةٌ بآلاف غيرها تكفي، نظرياً، لتمثيل أيِّ دالّةٍ مستمرّة؛ السحرُ ليس في العصبون بل في التركيب.»

الأجزاء السابقة أعطتنا التفاضل (2) والتحسين (4) ونظرية التعلّم (6). الآن ننتقل إلى **قلب التعلّم العميق**: كيف يُبنى «العصبون» الاصطناعي، وكيف تتركّب العصبونات في شبكةٍ أمامية، ولماذا تَعِدُنا النظريات الرياضية بأن شبكةً «واسعةً كفاية» أو «عميقةً كفاية» يمكنها تقريب أيِّ دالّةٍ مستمرّة بدقّةٍ تعسُفية. هذا الفصل يضع الأساس الجبري والهندسي لكلّ ما يأتي في الأجزاء 7–8: الانتشار العكسي (36)، الالتفاف (37)، المتكرّرات (38)، المحوّلات (39)، ونواة التماس العصبية (40).
سبع نظريات:

- **2.35 البيرسيبترون ونظرية التقارب (Novikoff)** — متى يتوقّف التعلّم وكم خطأً يرتكب؟
- **3.35 معمارية الشبكة الأمامية والتمثيل بالتركيب** — الشبكةُ كتركيبٍ لطبقاتٍ أفينيةٍ وتنشيطية.
- **4.35 دوال التنشيط وخصائصها** — السِّيجمويد، الـ$tanh$، والـ$ReLU$ وقابليتها للتقريب.
- **5.35 نظرية التقريب الشامل (طبقة واحدة مخفية — Cybenko/Hornik)** — كثافة فضاء الشبكة في $C(K)$.
- **6.35 التقريب الشامل المحدود بالعرض (Lu / Hanin–Sellke)** — العرض $n+1$ يكفي بعمقٍ كافٍ.
- **7.35 معدّل تقارب بارون** — تقييم $O(1/\sqrt{m})$ مستقلٌّ عن البُعد.
- **8.35 فصل العمق (Telgarsky / Montufar)** — العمقُ مضاعِفٌ أُسّيٌّ للتعبيرية.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
$\mathcal{X} = \mathbb{R}^d$	فضاء المُدخلات	d بُعد المُدخل
$x \in \mathbb{R}^d$	ناقل مُدخل	عيّنة واحدة
$w \in \mathbb{R}^d,\ b \in \mathbb{R}$	وزنٌ وتحيز	لمكوّن خطّي
$\sigma : \mathbb{R} \to \mathbb{R}$	دالّة التنشيط	سِيجمويد/$tanh$/$ReLU$
L	عمق الشبكة	عدد الطبقات غير الخطّية
d_ℓ	عرض الطبقة ℓ	عدد العصبونات فيها

$W^{(\ell)}, b^{(\ell)}$	مصفوفة أوزان وتحيزات الطبقة ℓ	الأبعاد $d_\ell \times d_{\ell-1}$
$z^{(\ell)}, a^{(\ell)}$	ما قبل التنشيط وبعده	$a^{(0)} = x$
$f(x;\theta)$	دالّة الشبكة	كلّ المعاملات θ
m	عدد عصبونات الطبقة المخفية	في نظريات التقريب
γ	الهامش	في البيرسيبترون
R	نصف قطر المُدخلات	$\max_i \|x_i\|$
$\mu,\ \hat{f}$	توزيع/مقياس، تحويل فوريه	في بارون
ε	دقّة التقريب	$\sup \|f-g\| < \varepsilon$
$C,\ B_2(f)$	ثابت، نرم بارون	في معدّل التقارب

الاتفاقيات: العيّنة $\mathcal{D}$ مجهولة؛ نرمز لـ $\mathbb{E}$ بالتوقّع تحت $\mathcal{D}$. دالّة التنشيط تُطبَّق جُملةً (element-wise) على النواقل. كلّ المعادلات في كتل LTR مستقلّة.

صياغة رسمية: البيرسيبترون (Rosenblatt 1958) يتعلّم وزناً $w \in \mathbb{R}^d$ وتوقّعَه $\hat{y} = \operatorname{sign}(w^\top x)$ (نضيف 1 إلى x لاحتواء التحيز). عند الخطأ حيث $y_i(w^\top x_i) \le 0$ نحدّث

$$w \ \leftarrow \ w + y_i\, x_i \tag{1.35}$$

نفترض الانفصال الخطّي بوجود $w^\star$ بوحدة الطول بحيث

$$y_i\big(w^{\star\top} x_i\big) \ \ge \ \gamma > 0 \quad \forall i, \qquad \|x_i\| \le R \tag{2.35}$$

فإن عدد الأخطاء T محدودٌ بـ

$$T \ \le \ \left\lceil \left(\frac{R}{\gamma}\right)^2 \right\rceil \tag{3.35}$$

جدول الرموز

الرمز	المعنى	ملاحظة
w	وزن المتعلّم	يبدأ بصفر عادةً
$x_i,\ y_i \in \{-1,+1\}$	نقطة وعُلامتها	بيانات التدريب
γ	الهامش	أصغر مسافة موقعة للفصل
R	أقصى نصف قطر $\max_i \|x_i\|$	
T	عدد الأخطاء	يُحَدُّ بالنسبة (3.35)
$w^\star$	«الفاصل الأمثل»	بوحدة الطول $\|w^\star\| = 1$

الرسم

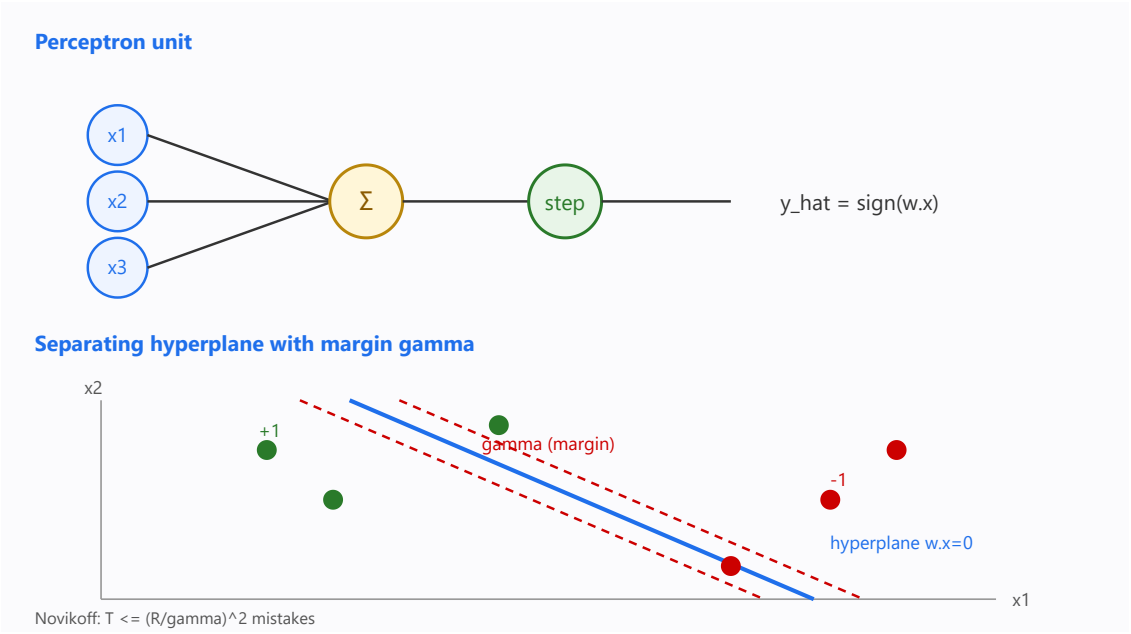
<figure>

<figcaption>الشكل 1.35: مستوٍ فاصل يفصل الصنفين بهامش γ عن أقرب نقطة؛ البيرسيبترون يحرّك w باتجاه النقاط المخطئة حتى يستقرّ.</figcaption>
</figure>

البرهان (Novikoff)

الخطوة 1 (تقدّم سُفلي): باقتراح $w_0 = 0$ فإن $w_T = \sum_{\text{أخطاء}} y_i x_i$، فنحصل

$$w_T^\top w^\star = \sum y_i\, x_i^\top w^\star \ \ge \ T\gamma \tag{1}$$



شكل ١.٣٥: *
البيرسيبترون ومستوي الفصل

لأن كلَّ مساهمة $\gamma \geq$ بالافتراض (2.35).

الخطوة 2 (نموٌّ سُلّمي): بالتكرار،

$$\|w_T\|^2 = \|w_{T-1} + y_i x_i\|^2 = \|w_{T-1}\|^2 + 2\, w_{T-1}^\top (y_i x_i) + \|x_i\|^2$$

وبما أنَّ الخطأ يعني $w_{T-1}^\top (y_i x_i) \leq 0$ وعلى الأكثر $\|x_i\|^2 \leq R^2$، فإن

$$\|w_T\|^2 \;\leq\; \|w_{T-1}\|^2 + R^2 \;\leq\; T\,R^2 \quad \Rightarrow \quad \|w_T\| \leq \sqrt{T}\,R \tag{2}$$

الخطوة 3 (الجمع): من (1) و(2) و$\|w_T\| \|w^\star\| = \|w_T\|$ (لأنَّ $\|w^\star\| = 1$):

$$T\gamma \;\leq\; \|w_T\| \;\leq\; \sqrt{T}\,R \quad \Rightarrow \quad \sqrt{T}\,\gamma \leq R \quad \Rightarrow \quad T \leq \left(\frac{R}{\gamma}\right)^2 \tag{3}$$

وبأخذ السقف نحصل (3.35). ■

الخطوة 4 (ملاحظة أساسية): الحدّ يعتمد على النسبة R/γ لا على عدد العيّنات n، فمهما كبرت العيّنة يبقى الحدّ نفسه متى تحقّق الانفصال. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.35): حساب الحدّ المباشر المعطيات: $R = 1,\ \gamma = 0.5$. المطلوب: أقصى عدد أخطاء. الحل: الخطوة 1: نطبّق (3.35): $T \leq (R/\gamma)^2 = (1/0.5)^2 = 4$. الخطوة 2: بالسقف $\lceil 4 \rceil = 4$. النتيجة: البيرسيبترون يرتكب على الأكثر 4 أخطاء ثمَّ يتوقّف. الربط بالذكاء الاصطناعي: هذا يبرّر تقاربَ التدريب على بيانات منفصلة خطّياً خلال عددٍ محدودٍ من العصور.

مثال (35.2-2): هامشٌ ضيّق المعطيات: $R = 2,\ \gamma = 0.25$. المطلوب: الحدّ. الحل: الخطوة 1: $T \le (2/0.25)^2 = (8)^2 = 64$. النتيجة: هامشٌ أضيقُ ربعَ السابق يرفع الحدّ $\times 4$ (لأنَّه تربيع النسبة). الربط بالذكاء الاصطناعي: صغرُ الهامش يبطئ التقارب تماماً كما في آلات المتّجهات الداعمة (SVM).

مثال (35.2-3): نقاطٌ على دائرة الوحدة المعطيات: $R = \sqrt{2} \approx 1.414,\ \gamma = 1$. المطلوب: الحدّ. الحل: الخطوة 1: $T \le (\sqrt{2}/1)^2 = 2$. النتيجة: حدٌّ صغير جداً لأنَّ النقاط قريبة من المركز لكنَّ الهامش كامل. الربط بالذكاء الاصطناعي: جودةُ الفصل (الهامش) أهمُّ من كبر نصف القطر وحده.

مثال (35.2-4): أثر مضاعفة الهامش المعطيات: من γ إلى 2γ مع ثبات R. المطلوب: نسبة تغيّر الحدّ. الحل: الخطوة 1: القديم $(R/\gamma)^2$، الجديد $(R/(2\gamma))^2 = (R/\gamma)^2/4$. النتيجة: مضاعفة الهامش تربعُ الحدَّ (تقليلٌ بعامل 4). الربط بالذكاء الاصطناعي: المُعالجة المسبقة التي تكبّر الهامش (مثل التوحيد) تسريعٌ فعّال للتقارب.

مثال (35.2-5): تشغيلٌ يدويٌّ على مستوًى ثنائي المعطيات: $p_1 = (1,0), y_1 = +1$؛ $p_2 = (-1,0), y_2 = -1$؛ نبدأ $w = (0,0)$ ونعتمد $\operatorname{sign}(0) = +1$. المطلوب: تتبّع التحديثات حتى الفصل. الحل: الخطوة 1: على p_1: $w^\top p_1 = 0 \le 0$ خطأ $\to w \leftarrow (0,0) + 1 \cdot (1,0) = (1,0)$. الخطوة 2: على p_2: $0 \le w^\top p_2 = -1$ خطأ $\to w \leftarrow (1,0) + (-1)(-1,0) = (2,0)$. الخطوة 3: إعادة p_1: $2 \cdot 1 = 2 > 0$ صحيح؛ p_2: $2 \cdot (-1) = -2 < 0$ صحيح. النتيجة: توقّف بعد خطأين؛ $w = (2,0)$ يفصل. الحدّ النظري $R = 1, \gamma = 1 \Rightarrow T \le 1$؟ هنا γ الفعلي $= \min |y_i w^\top x_i|/\|w\| = 1/2$، فيتّفق $T \le (R/\gamma)^2 = (1/0.5)^2 = 4 \ge 2$. الربط بالذكاء الاصطناعي: الترتيبُ يغيّر عدد الأخطاء لكنَّ الحدَّ الأعلى ثابت.

مثال (35.2-6): اشتقاق الهامش من الحدّ المعطيات: $R = 1$ ونريد $T \le 100$. المطلوب: أقصى هامش مطلوب. الحل: الخطوة 1: $(R/\gamma)^2 = (1/\gamma)^2 \ge 100 \Rightarrow \gamma \ge 1/10 = 0.1$. النتيجة: $\gamma \ge 0.1$ يكفي لضمان ≤ 100 خطأ. الربط بالذكاء الاصطناعي: اختيارُ ميزاتٍ تضمن هامشاً 0.1 على الأقل يحدُّ عدد العصور.

مثال (35.2-7): أثر تصغير نصف القطر المعطيات: $\gamma = 0.1$ وR ينتقل $0.5 \to 1$. المطلوب: الحدّ الجديد. الحل: الخطوة 1: القديم $(1/0.1)^2 = 100$؛ الجديد $(0.5/0.1)^2 = 25$. النتيجة: تصغيرُ المدخلات (توحيد المقياس) يربّعُ تحسينَ الحدّ. الربط بالذكاء الاصطناعي: التوحيد (standardization) يسرّع البيرسيبترون وشبكات الانحدار اللوجستي.

مثال (35.2-8): إيجاد فاصل وهامش المعطيات: $a = (1,0), y = +1$؛ $b = (0,1), y = +1$؛ $c = (-1,-1), y = -1$؛ $R = \sqrt{2}$. المطلوب: $w^\star$ والهامش. الحل: الخطوة 1: نختبر $w^\star = (1,1)/\sqrt{2}$: نقاط a, b تعطي $1 > 0$؛ نقطة c تعطي $-1(-1-1)/\sqrt{2} = -\sqrt{2} < 0$. الخطوة 2: الهامش $\gamma = \min\{1, 1, \sqrt{2}\} = 1$. النتيجة: $T \le (\sqrt{2}/1)^2 = 2$. الربط بالذكاء الاصطناعي: خوارزمياتُ الهامش (SVM) تجد أكبر γ فعلياً.

مثال (35.2-9): هامشٌ صفريٌّ = لا تقارب المعطيات: $w^\star = (1,0)$، نقطة $+1$: $(2,0), y = +1$ ونقطة -1: $(0,1), y = -1$. المطلوب: هل تنفصل؟ الحل: الخطوة 1: نقطة $(0,1)$ تعطي $w^{\star\top} x = 0 \to$ لا هامشَ موجباً. النتيجة: $\gamma = 0$ فيجعل الحدَّ لانهائياً؛ البيانات غير منفصلةٍ بهذا $w^\star$. الربط بالذكاء الاصطناعي: غيابُ الهامش يفسّر عدمَ تقارب البيرسيبترون على البيانات غير المنفصلة.

مثال (35.2-10): إدخال التحيز بالتمديد المعطيات: نقطة $+1$: $(0,0), y = +1$ مع نقاط على محور x موجبة/سالبة. المطلوب: جعلها منفصلةً بتمديد $(x,1) \leftarrow x$. الحل: الخطوة 1: نمدد كلَّ نقطة بإحداثيَّة 1؛ يصبح التحيز وزناً عادياً. الخطوة 2: نختار $w = (0,1)$ الممدد $\to$ النقطة $(0,0,1)$ تعطي $+1$ (صحيح). النتيجة: التمديد يحوّل الانفصال الخطّي المتمركز إلى منفصلٍ بـw ممدد. الربط بالذكاء الاصطناعي: طبقاتُ الشبكات تستخدم فعلاً متّجهَ تحيزٍ مستقلّ.

مثال (35.2-11): عدد العصور المعطيات: $n = 20$ نقطة و$T \le 4$. المطلوب: حدَّ الأخطاء لكلِّ عصر. الحل:

الخطوة 1: كلُّ عصر يمرّ على 20 نقطة؛ إجمالي الأخطاء ≤ 4. النتيجة: عصران كافيان على الأرجح (4 خطأ على الأكثر). الربط بالذكاء الاصطناعي: عددُ العصور في التدريب محدودٌ نظرياً عند الانفصال.

مثال (12-2.35): عدم تأثّر الحدّ بقياس مشترك المعطيات: قِياس كلِّ x_i بـ2 $\Rightarrow R \to 2R \Rightarrow w^\star \to w^\star/2$ و$\gamma \to 2\gamma$. المطلوب: هل يتغيّر الحدّ؟ الحل: الخطوة 1: النسبة $R/\gamma = (2R)/(2\gamma)$ ثابتة. النتيجة: الحدّ $(R/\gamma)^2$ لا يتغيّر بالقياس المتجانس. الربط بالذكاء الاصطناعي: قياسُ المدخلات لا يغيّر قابليةَ الفصل النظريّة.

مثال (13-2.35): ضرورة فرض الانفصال المعطيات: بيانات متداخلة (AND vs XOR). المطلوب: ماذا يحدث بلا انفصال؟ الحل: الخطوة 1: بلا $\gamma > 0$ يستمرُّ التحديث إلى الأبد. النتيجة: النظرية لا تضمن التوقّف إلاّ بالانفصال. الربط بالذكاء الاصطناعي: لهذا نحتاج شبكاتٍ أعمقَ أو ميزاتِ نواةٍ لـXOR.

مثال (14-2.35): حالة أحاديّة البُعد المعطيات: $x = 1, y = +1$ و$x = -1, y = -1$؛ w عدديّ. المطلوب: الحدّ والتشغيل. الحل: الخطوة 1: $R = 1, \gamma = 1 \Rightarrow T \leq 1$. الخطوة 2: من $w = 0$ خطأ عند $x = -1 \to +(-1)(-1) = 1$ $\leftarrow w$ يفصل. النتيجة: توقّف بخطأ واحد. الربط بالذكاء الاصطناعي: في 1D الانفصالُ يعني إيجاد عتبة.

مثال (15-2.35): خوارزمية الجيب (Pocket) المعطيات: $T \leq 4$ خلال تمريرة، $n = 20$. المطلوب: أقصى نسبة خطأ أثناء التشغيل. الحل: الخطوة 1: $4/20 = 0.20$. النتيجة: لا تتجاوز أخطاءُ التدريب 20٪؟ بل هذا حدٌّ لأخطاء التحديث لا للتصنيف النهائي. الربط بالذكاء الاصطناعي: نحتفظ بأفضل w (الجيب) لتقليل خطأ الاختبار.

أخطاء شائعة

- **الخلط بين R والهامش:** الحدّ $(R/\gamma)^2$ تربيعيٌّ في النسبة لا في كلٍّ وحده.
- **نسْي التحيز:** إغفال تمديد x يجعل الفصل المتمركز مستحيلاً.
- **افتراض التوقّف دائماً:** النظرية تشترط الانفصال، وإلاّ لا حدَّ ولا توقّف.
- **القول بأنَّ الحدّ يتناقص مع n:** الحدّ لا يعتمد على حجم العيّنة بل على الهندسة.
- **خلط γ بالدقّة:** الهامش هندسيٌّ وليس معدّل خطأ.

صياغة رسمية: شبكةٌ أماميةٌ بعمق L وأبعاد $d_0 = d,\ d_1, \ldots, d_L$ تحسب

$$z^{(\ell)} = W^{(\ell)} a^{(\ell-1)} + b^{(\ell)}, \qquad a^{(\ell)} = \sigma^{(\ell)}\big(z^{(\ell)}\big), \qquad a^{(0)} = x \tag{4.35}$$

$$f(x;\theta) = a^{(L)}, \qquad \theta = \big\{W^{(\ell)}, b^{(\ell)}\big\}_{\ell=1}^{L} \tag{5.35}$$

بوصفها تركيباً: $f = (\sigma_L \circ A_L) \circ \cdots \circ (\sigma_1 \circ A_1)$ حيث A_ℓ أفينيّ. عدد المعاملات

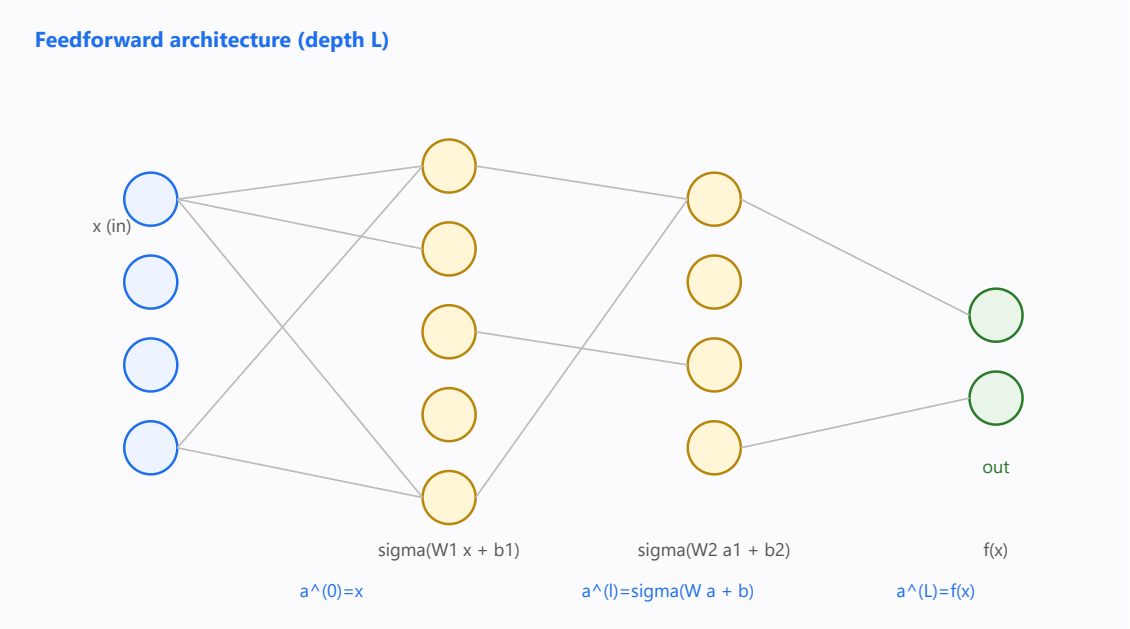
$$N_{\text{param}} = \sum_{\ell=1}^{L} \big(d_\ell d_{\ell-1} + d_\ell\big) \tag{6.35}$$

جدول الرموز

الرمز	المعنى	ملاحظة
L	العمق	عدد الطبقات
d_ℓ	عرض الطبقة ℓ	عدد العصبونات
$W^{(\ell)}$	مصفوفة الأوزان	أبعاد $d_\ell \times d_{\ell-1}$
$z^{(\ell)}, a^{(\ell)}$	ما قبل/بعد التنشيط	$a^{(0)} = x$
$\sigma^{(\ell)}$	التنشيط بالطبقة	غالباً متطابق
N_{param}	عدد المعاملات	يقيس السعة

الرسم

<figure> الشكل<figcaption> 2.35: طبقاتٌ متّصلةٌ كُلاً بكلٍّ؛ كلُّ طبقة أفينيّة ثمّ تنشيط، والعمق L عدد



شكل ٢.٣٥: *
معمارية الشبكة الأمامية

التركيبات.</figcaption> </figure>

البرهان (تأسيسي)

الخطوة 1 (استقراء على الطبقات): بِناءً على (4.35) فإنَّ $a^{(1)} = \sigma_1(A_1(x))$ دالّةٌ في x؛ وبالتعريف $a^{(2)} = \sigma_2(A_2(a^{(1)}))$ دالّةٌ في $a^{(1)}$ أي في x؛ وهكذا حتى $a^{(L)}$. ■

الخطوة 2 (حساب المعاملات): الطبقة ℓ لها مصفوفة $W^{(\ell)}$ فيها $d_\ell d_{\ell-1}$ عدداً وتحيز d_ℓ؛ جمعها يعطي (6.35). ■

الخطوة 3 (التركيب): بوضع $A_\ell(x) = W^{(\ell)}x + b^{(\ell)}$ نحصل صراحةً على $f = (\sigma_L \circ A_L) \circ \cdots$، ما يثبت أنَّ الشبكة تركيبٌ لا جمعٌ خطّيٌّ بسيط. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.35): عمارة تصنيف الصور الكلاسيكية المعطيات: $[784, 256, 64, 10]$. المطلوب: عدد المعاملات. الحل: الخطوة 1: الطبقة1: $784 \cdot 256 + 256 = 200704 + 256 = 200960$. الخطوة 2: الطبقة2:

$64 \cdot 10 + 10 = 640 + 10 = 650$. الخطوة 3: الطبقة $256 \cdot 64 + 64 = 16384 + 64 = 16448$. الخطوة 4: المجموع $200960 + 16448 + 650 = 218058$. النتيجة: $N_{\text{param}} = 218{,}058$. الربط بالذكاء الاصطناعي: هذا حجمٌ معتدل يوضّح أنَّ الطبقات العريضة تهيمن على المعاملات.

مثال (35.3-2): شبكة صغيرة المعطيات: $[4, 8, 8, 2]$. المطلوب: N_{param}. الحل: الخطوة 1: $8 \cdot 4 \cdot 8 + 8 = 40$؛ $8 + 8 = 72$؛ $8 \cdot 2 + 2 = 18$. الخطوة 2: $40 + 72 + 18 = 130$. النتيجة: 130 معاملاً. الربط بالذكاء الاصطناعي: نماذجُ الهواتف تستخدم ملايين المعاملات لهذا نحتاج ضغطاً.

مثال (35.3-3): تمريرٌ أماميٌّ يدوي المعطيات: $x = [1, 2]^\top$، $W^{(1)} = I_2$، $b^{(1)} = 0$، $\sigma = \text{ReLU}$، $W^{(2)} = [1, 1]$، $b^{(2)} = 0$. المطلوب: $f(x)$. الحل: الخطوة 1: $z^{(1)} = I_2[1, 2]^\top = [1, 2]^\top$؛ $a^{(1)} = \text{ReLU}([1, 2]) = [1, 2]$. الخطوة 2: $z^{(2)} = [1, 1][1, 2]^\top = 3$؛ $a^{(2)} = 3$. النتيجة: $f(x) = 3$. الربط بالذكاء الاصطناعي: هذا أساسُ كلِّ استدلالٍ (inference) في الشبكات.

مثال (35.3-4): مع $tanh$ المعطيات: $x = [0, 1]^\top$، $W^{(1)} = [[1, 0], [1, 0]]$، $b^{(1)} = 0$، $\sigma = \tanh$، $W^{(2)} = [1, 1]$، $b^{(2)} = 0$. المطلوب: $f(x)$. الحل: الخطوة 1: $z^{(1)} = [0, 1]^\top$؛ $a^{(1)} = [\tanh 0, \tanh 1] = [0, 0.7616]$. الخطوة 2: $z^{(2)} = 1 \cdot 0 + 1 \cdot 0.7616 = 0.7616$. النتيجة: $f(x) = 0.7616$. الربط بالذكاء الاصطناعي: التانح يُبقي القيم متمركزة حول الصفر.

مثال (35.3-5): عمقٌ مقابل عرض المعطيات: $d = 5$، عمارة $[5, 10, 10, 1]$ مقابل $[5, 20, 1]$. المطلوب: مقارنة المعاملات. الحل: الخطوة 1: العميقة: $181 = 1{+}10{+}10{+}100{+}10{+}10 = 1{+}1{\cdot}10{+}10{+}10{\cdot}10{+}10{+}1{\cdot}10{+}5$. الخطوة 2: الواسعة: $141 = 1 + 20 + 20 + 100 + 1 = 5 \cdot 20 + 20 + 20 \cdot 1 + 1$. النتيجة: العميقة أكثر معاملاتٍ قليلاً لكنَّها أعبر تعبيراً. الربط بالذكاء الاصطناعي: مقدّمة لفصل 8.35 (فصل العمق).

مثال (35.3-6): ثلاث طبقات مخفية المعطيات: $[2, 4, 4, 4, 1]$. المطلوب: N_{param}. الحل: الخطوة 1: $2{\cdot}4{+}4 = 12$؛ $4 \cdot 4 + 4 = 20$ (مرتان)؛ $4 \cdot 1 + 1 = 5$. الخطوة 2: $12 + 20 + 20 + 5 = 57$. النتيجة: 57 معاملاً. الربط بالذكاء الاصطناعي: كلُّ طبقةٍ مخفيةٍ تضيف كتلةً من المعاملات.

مثال (35.3-7): توسيعٌ صريح المعطيات: x عدديٌّ، $W^{(1)} = 2, b^{(1)} = 0, \sigma = \text{ReLU}, W^{(2)} = -1, b^{(2)} = 3$. المطلوب: صيغة $f(x)$ مباشرة. الحل: الخطوة 1: $z^{(1)} = 2x$؛ $a^{(1)} = \text{ReLU}(2x)$. الخطوة 2: $f = 3\,\text{ReLU}(2x) - 1$. الخطوة 3: $f(0.5) = 3 \cdot 1 - 1 = 2$؛ $f(-1) = 3 \cdot 0 - 1 = -1$. النتيجة: $f(x) = 3\,\text{ReLU}(2x) - 1$. الربط بالذكاء الاصطناعي: رؤيةُ الصيغة المغلقة تُسهّل التفاضل لاحقاً.

مثال (35.3-8): صيغة تقريبية للأبعاد المتساوية المعطيات: كلُّ W وعرض ثابت $d_\ell = W = 100, L = 10$. المطلوب: تقريب N_{param}. الحل: الخطوة 1: $N \approx L(W^2 + W)$. الخطوة 2: لـ $10(10000 + 100) =:$. النتيجة: $\approx 1{,}010{,}000$ مليون معاملاً. الربط بالذكاء الاصطناعي: نماذجُ GPT الكبيرة بمليارات المعاملات من هذا القبيل.

مثال (35.3-9): طبقة خطّية لا تزيد التعبير المعطيات: طبقة بـ σ = identity مُضافة. المطلوب: تأثيرها على f. الحل: الخطوة 1: تركيبُ أفينيَّين متتاليين لا يزال أفينيّاً. الخطوة 2: تزيد المعاملات لكنَّها لا تزيد تعبيرَ الطبقة المفردة. النتيجة: عمق «أفينيٌّ فقط» يكافئ طبقةً واحدة. الربط بالذكاء الاصطناعي: «عدم الخطّية» ضروري وإلاّ انهارت الشبكة لخطّي.

مثال (35.3-10): أشكال الدُّفعات المعطيات: $[d = 3, 5, 2]$، حجم دفعة $n = 4$. المطلوب: أبعاد $a^{(1)}, a^{(2)}$. الحل: الخطوة 1: $a^{(1)}$: 5×4؛ $3 \times 4 \times 5 \cdot 5 = z^{(2)}$؟ لا، $W^{(2)}$ أبعاد 2×5 فـ $2 \times 4 = z^{(2)}$. النتيجة: $a^{(1)} \in \mathbb{R}^{4 \times 5}$، $a^{(2)} \in \mathbb{R}^{4 \times 2}$. الربط بالذكاء الاصطناعي: الحوسبةُ المتجهة (vectorization) تُعلِمُ هذه الأبعاد.

مثال (35.3-11): وصلٌ متبقٍّ (Residual) المعطيات: $[10, 10, 10]$ مع وصل $f(x) = x + g(x)$. المطلوب:

هل تزيد المعاملات؟ الحل: الخطوة 1: المعاملات الأصلية $220 = 10 + 10 \cdot 10 + 10 + 10 \cdot 10$. الخطوة 2: الوصل يضيف الفرع g بنفس العدد لا الهويّة. النتيجة: تبقى 220 للمعاملات القابلة للتعلم. الربط بالذكاء الاصطناعي: الـResNet يعمّق بلا انفجار في المعاملات.

مثال (12-3.35): تحويل التفافٍ إلى مصفوفة المعطيات: conv 1D بإتلاف 1 يعادل مصفوفة Toeplitz.

المطلوب: مبدأ الحساب. الحل: الخطوة 1: كلُّ نافذة خطّية في مدخلات سابقة $\rightarrow$ صفٌّ في مصفوفة. الخطوة 2: العرضُ يكبر لكنَّ البنية متفرّقة. النتيجة: الالتفاف حالةٌ خاصةٌ من الأفيني المتفرّق (يفصّل في 37). الربط بالذكاء الاصطناعي: هذا يربط 3.35 بفصل الالتفاف.

مثال (13-3.35): أصغر مصنّف ثنائي المعطيات: $[1, 2, 2]$. المطلوب: N_{param}. الحل: الخطوة 1: $1 \cdot 2 + 2 = 4$؛ $2 \cdot 2 + 2 = 6$؛ المجموع 10. النتيجة: 10 معاملات. الربط بالذكاء الاصطناعي: أصغر شبكةٍ لها طبقةٌ مخفية.

مثال (14-3.35): ربط بالسعة (VC) المعطيات: زيادة N_{param} تكبّر $\mathcal{H}$. المطلوب: علاقة بالجزء 6. الحل: الخطوة 1: بُعد VC يكبر تقريباً مع المعاملات. النتيجة: مزيدٌ من المعاملات $\Rightarrow$ سعةٌ أعلى $\Rightarrow$ خطر إفراط (Overfitting). الربط بالذكاء الاصطناعي: لهذا نُنظِّم (Ch30) ونخفّض العرض.

مثال (15-3.35): تكلفة الحوسبة المعطيات: $N = 218{,}058$ (مثال 1-3.35). المطلوب: تقريب عمليات التمرير. الحل: الخطوة 1: كلُّ معاملة $\approx$ عمليتا ضرب/جمع $\Rightarrow 2N$. الخطوة 2: $2 \cdot 218058 \approx 436{,}116$ عملية لكلِّ عيّنة. النتيجة: $\approx$436k FLOP لكلِّ استدلال. الربط بالذكاء الاصطناعي: استدلالٌ خفيفٌ يتيح تشغيله على الأجهزة المحمولة.

أخطاء شائعة

- **نسيان التحيز في العدّ:** $b^{(\ell)}$ يضيف d_ℓ معاملاً لا تُنسَ.
- **الظنّ أنَّ العمق وحده يكفي بلا عرض:** الطبقة بعرض 1 محدودة جداً.
- **إهمال عدم الخطّية:** سلسلةٌ أفينيةٌ = أفينيّةٌ واحدة.
- **خلط d_ℓ كمخرجات الطبقة السابقة:** $d_{\ell-1}$ هو مدخل الطبقة ℓ.
- **احتساب FLOP كـN لا $2N$:** كلُّ وزن عمليتان.

صياغة رسمية: دالّة التنشيط $\sigma : \mathbb{R} \to \mathbb{R}$ تُطبَّق جُملةً. الثلاثة القياسية:

$$\sigma_{\text{sig}}(t) = \frac{1}{1 + e^{-t}}, \qquad \sigma'_{\text{sig}}(t) = \sigma_{\text{sig}}(t)\big(1 - \sigma_{\text{sig}}(t)\big) \tag{7.35}$$

$$\tanh(t) = \frac{e^{t} - e^{-t}}{e^{t} + e^{-t}}, \qquad \tanh'(t) = 1 - \tanh^2(t) \tag{8.35}$$

$$\text{ReLU}(t) = \max(0, t), \qquad \text{ReLU}'(t) = \mathbf{1}_{t>0} \tag{9.35}$$

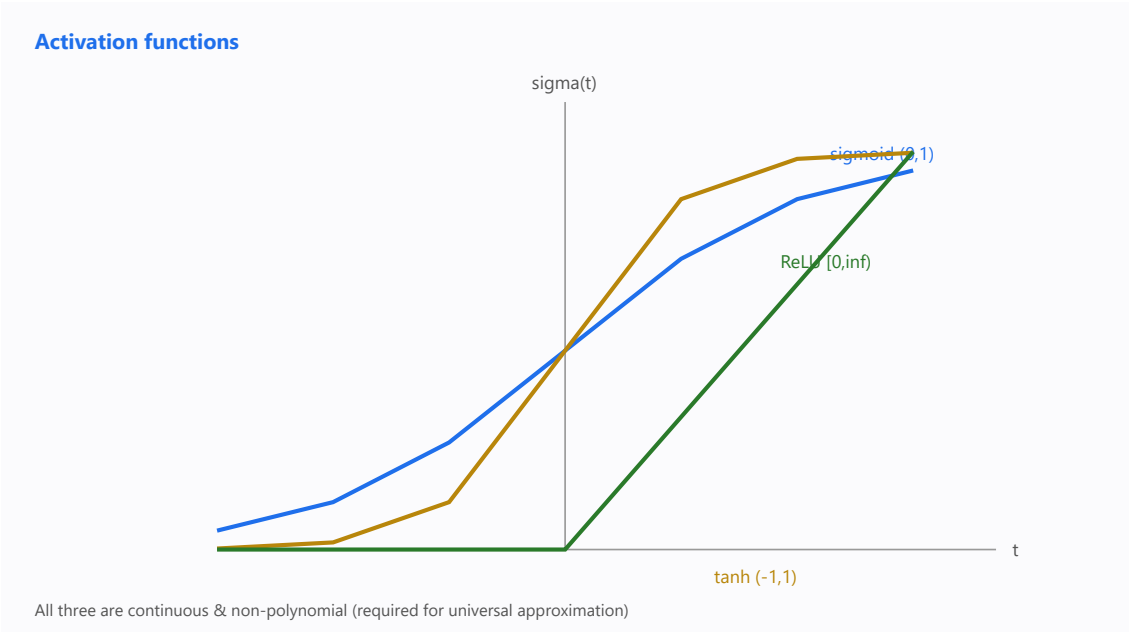
الخاصيةُ الحاسمة للتقريب الشامل (5.35): σ **مستمرّةٌ غير كثيرة الحدود** (non-polynomial)؛ الثلاثة جميعها تحقّقها.

جدول الرموز

الرمز	المعنى	ملاحظة
σ_{sig}	السِّيجمويد	مجال $(0,1)$
tanh	الظلّ الزائدي	مجال $(-1,1)$
ReLU	الوحدة الخطّية المصحّحة	مجال $[0,\infty)$
$\mathbf{1}_{t>0}$	مؤشّر	مشتقّة ReLU
non-polynomial	غير كثيرة الحدود	شرط التقريب

الرسم

<figure> الشكل<figcaption> 3.35: السِّيجمويد والـ$tanh$ محدودتان ومتصلاّنتان؛ الـ$ReLU$ خطّيّةٌ جزئياً غير قابلة



شكل ٣٥.٣: *
دوال التنشيط

للاشتقاق عند الصفر.<figcaption/> </figure>

البرهان (خصائص)

الخطوة 1 (مشتقّة السِّيجمويد): $\sigma' = e^{-t}/(1+e^{-t})^2 = \sigma(1-\sigma)$ من تفكيك المقام. ■

الخطوة 2 (مشتقّة الـ$tanh$): $\tanh' = \frac{(e^t+e^{-t})^2-(e^t-e^{-t})^2}{(e^t+e^{-t})^2} = 1-\tanh^2$. ■

الخطوة 3 (ReLU غير كثيرة حدود): لو كانت كثيرة حدودٍ لكانت مشتقّاتها مرتبةٍ تنعدم ابتداءً من رتبة ما، لكنَّ ReLU لها مشتقّات لا تنتهي عند $t \neq 0$ بشكل غير منتهٍ الصفر، وهي متعدّدة التعريف لا كثيرة حدودٍ واحدة. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.35): قيم السِّيجمويد المعطيات: $t = 0, 2, -2$. المطلوب: $\sigma_{\text{sig}}(t)$. الحل: الخطوة 1: $\sigma(0) = 1/2 = 0.5$. الخطوة 2: $\sigma(2) = 1/(1+e^{-2}) = 1/(1+0.1353) = 0.8808$. الخطوة 3: $\sigma(-2) = 1/(1+e^{2}) = 1/(1+7.389) = 0.1192$. النتيجة: $\{0.5, 0.8808, 0.1192\}$. الربط بالذكاء الاصطناعي: السِّيجمويد يحوّل الأعداد إلى احتمالات.

مثال (35.4-2): مشتقّة السِّيجمويد المعطيات: $t = 2$. المطلوب: $\sigma'(2)$. الحل: الخطوة 1: $\sigma'(2) = 0.1050$. الخطوة 2: $0.8808 \cdot 0.1192 = 0.8808(1 - 0.8808) = 0.1050$. النتيجة: 0.1050. الربط بالذكاء الاصطناعي: يستخدم في الانتشار العكسي (Ch36).

مثال (35.4-3): قيم $tanh$ المعطيات: $t = 1, -1, 0$. المطلوب: $\tanh(t)$. الحل: الخطوة 1: $\tanh(1) = (e - e^{-1})/(e + e^{-1}) = (2.7183 - 0.3679)/(2.7183 + 0.3679) = 2.3504/3.0862 = 0.7616$. الخطوة 2: $\tanh(-1) = -0.7616$، $\tanh(0) = 0$. النتيجة: $\{0.7616, -0.7616, 0\}$. الربط بالذكاء الاصطناعي: $tanh$ متمركز حول الصفر يسرّع التعلّم.

مثال (35.4-4): مشتقّة $tanh$ المعطيات: $t = 1$. المطلوب: $\tanh'(1)$. الحل: الخطوة 1: $1 - 0.7616^2 = 1 - 0.5800 = 0.4200$. النتيجة: 0.4200. الربط بالذكاء الاصطناعي: أكبر من مشتقّة السِّيجمويد عند النقطة نفسها.

مثال (35.4-5): ReLU عند نقاط المعطيات: $t = 0.5, -3$. المطلوب: القيمة والمشتقّة. الحل: الخطوة 1: $\text{ReLU}(0.5) = 0.5$، مشتقّة 1. الخطوة 2: $\text{ReLU}(-3) = 0$، مشتقّة 0. النتيجة: $\{0.5, 0\}$ وقيم المشتقّة $\{1, 0\}$. الربط بالذكاء الاصطناعي: ReLU لا يشبعُ موجباً $\Rightarrow$ لا تلاشي تدرّج.

مثال (35.4-6): تشبّع السِّيجمويد المعطيات: $t = 6, -6$. المطلوب: القيمة والمشتقّة. الحل: الخطوة 1: $\sigma(6) = 1/(1 + e^{-6}) = 1/(1 + 0.00248) = 0.9975$. الخطوة 2: $\sigma'(6) = 0.9975 \cdot 0.0025 = 0.0025$. النتيجة: تدرّجٌ شبه منعدم (vanishing). الربط بالذكاء الاصطناعي: التشبّع يُبطئ التعلّم في الطبقات العميقة.

مثال (35.4-7): علاقة $tanh$ بالسِّيجمويد المعطيات: $\tanh(t) = 2\sigma_{\text{sig}}(2t) - 1$. المطلوب: تحقّق عند $t = 1$. الحل: الخطوة 1: $\tanh(1) = 0.7616 = 2 \cdot 0.8808 - 1 = 2\sigma(2) - 1$. النتيجة: متطابقتان بعد قياس. الربط بالذكاء الاصطناعي: لذا تعلُّمُ $tanh$ يكافئ سِّيجمويد مقياساً.

مثال (35.4-8): LeakyReLU المعطيات: $\text{LReLU}(t) = \max(0.01t, t)$. المطلوب: $t = 2, -2$. الحل: الخطوة 1: $\text{LReLU}(2) = 2$؛ $\text{LReLU}(-2) = \max(-0.02, -2) = -0.02$. النتيجة: $\{-2 \to -0.02,\ 2 \to 2\}$. الربط بالذكاء الاصطناعي: «تسريب» بسيط يمنع العصبون الميت.

مثال (35.4-9): Swish المعطيات: $\text{Swish}(t) = t\,\sigma_{\text{sig}}(t)$. المطلوب: $t = 2, -2$. الحل: الخطوة 1: $\text{Swish}(2) = 2 \cdot 0.8808 = 1.7616$. الخطوة 2: $\text{Swish}(-2) = -2 \cdot 0.1192 = -0.2384$. النتيجة: $\{1.7616, -0.2384\}$. الربط بالذكاء الاصطناعي: swish يُستخدم في EfficientNet.

مثال (35.4-10): تقريب GELU المعطيات: $\text{GELU}(t) \approx 0.5t(1 + \tanh(0.797t + 0.035t^3))$. المطلوب: $\text{GELU}(1)$. الحل: الخطوة 1: $0.797 + 0.035 = 0.832$؛ $\tanh(0.832) = 0.6846$. الخطوة 2: $0.5 \cdot 1 \cdot (1 + 0.6846) = 0.8423$. النتيجة: 0.8423. الربط بالذكاء الاصطناعي: GELU في محوّلات BERT/GPT.

مثال (35.4-11): إثبات «غير كثيرة حدود» المعطيات: $\sigma(t) = t^2$ (كثيرة حدود). المطلوب: هل تصلح للتقريب الشامل؟ الحل: الخطوة 1: مجموع $c_j(t^2)$ يبقى كثيرة حدودٍ من الدرجة 2. الخطوة 2: لا يمثّل e^t مثلاً. النتيجة: كثيرة الحدود لا تكفي (تحتاج شرط non-polynomial). الربط بالذكاء الاصطناعي: هذا يفسّر اشتراط غير كثيرة الحدود في 35.5.

مثال (35.4-12): مجالات القيم المعطيات: أنواع التنشيط. المطلوب: المجال لكلٍّ. الحل: الخطوة 1: $\sigma_{\text{sig}} \in (0, 1)$؛ $\tanh \in (-1, 1)$؛ $\text{ReLU} \in [0, \infty)$. النتيجة: محدودةٌ أولُ اثنين، غير محدودةٍ. الربط بالذكاء الاصطناعي: ReLU القيم غير المحدودة تتطلّب تنظيماً للأوزان.

مثال (35.4-13): طبقة تنشيط المعطيات: $z = [3, -1]$. المطلوب: $a = \sigma_{\text{sig}}(z)$. الحل: الخطوة 1: $\sigma(3) = 1/(1 + e^{-3}) = 0.9526$؛ $\sigma(-1) = 0.2689$. النتيجة: $a = [0.9526, 0.2689]$. الربط بالذكاء الاصطناعي: كلُّ عصبونٍ يمرّ عبر السِّيجمويد.

مثال (35.4-14): وحداتٌ ميتة المعطيات: كلُّ $z_i < -5$ في طبقة سِّيجمويد. المطلوب: مشتقّاتها. الحل: الخطوة

1: $\sigma(-5) = 1/(1+e^{5}) = 0.0067$، $\sigma'(-5) = 0.0067 \cdot 0.9933 = 0.0066$. النتيجة: تدرّجٌ شبه معدوم $\Rightarrow$ لا تعلّم. الربط بالذكاء الاصطناعي: دافعٌ لاستخدام ReLU في الطبقات المخفية.

مثال (15-4.35): اختيار تنشيط المخرجات المعطيات: تصنيف 3 فئات، $z = [2, 0, -1]$. المطلوب: احتمالات softmax. الحل: الخطوة 1: $e^{2} = 7.389$، $e^{0} = 1$، $e^{-1} = 0.3679$، المجموع 8.7569. الخطوة 2: الاحتمالات $[0.8438, 0.1142, 0.0420]$. النتيجة: الفئة الأولى الأرجح. الربط بالذكاء الاصطناعي: softmax + إنتروبيا تقاطعية (Ch27).

أخطاء شائعة

- **استخدام ReLU في المخرجات:** موجبٌ دائماً لا يصلح للقيم السالبة.
- **نسيان عدم اشتقاق ReLU عند 0:** نعتمد المشتقّة اليمنى 1.
- **الظنّ بأنَّ السِّيجمويد أفضل من ReLU:** تشبّعها يضرّ بالعمق.
- **خلط المجال:** tanh يخرج سالباً والسِّيجمويد لا.
- **تطبيق التنشيط على المصفوفة بكاملها لا جُملةً:** النتيجة خاطئة أبعاداً.

صياغة رسمية (Cybenko 1989 / Hornik 1991): ليكن σ مستمرّاً محدوداً غير كثيرة حدودٍ (مثل السِّيجمويد). عرّف

$$\mathcal{F}_m = \left\{ g(x) = \sum_{j=1}^{m} c_j \, \sigma\!\left(w_j^{\top} x + b_j\right) \;:\; c_j \in \mathbb{R},\; w_j \in \mathbb{R}^d,\; b_j \in \mathbb{R} \right\} \tag{10.35}$$

فإنَّ $\mathcal{F}_m$ **كثيفةٌ** في $C(\mathcal{K})$ (دوالّ مستمرّة على جملةٍ مضغوطة $\mathcal{K} \subset \mathbb{R}^d$) بالمعيار المنتظم:

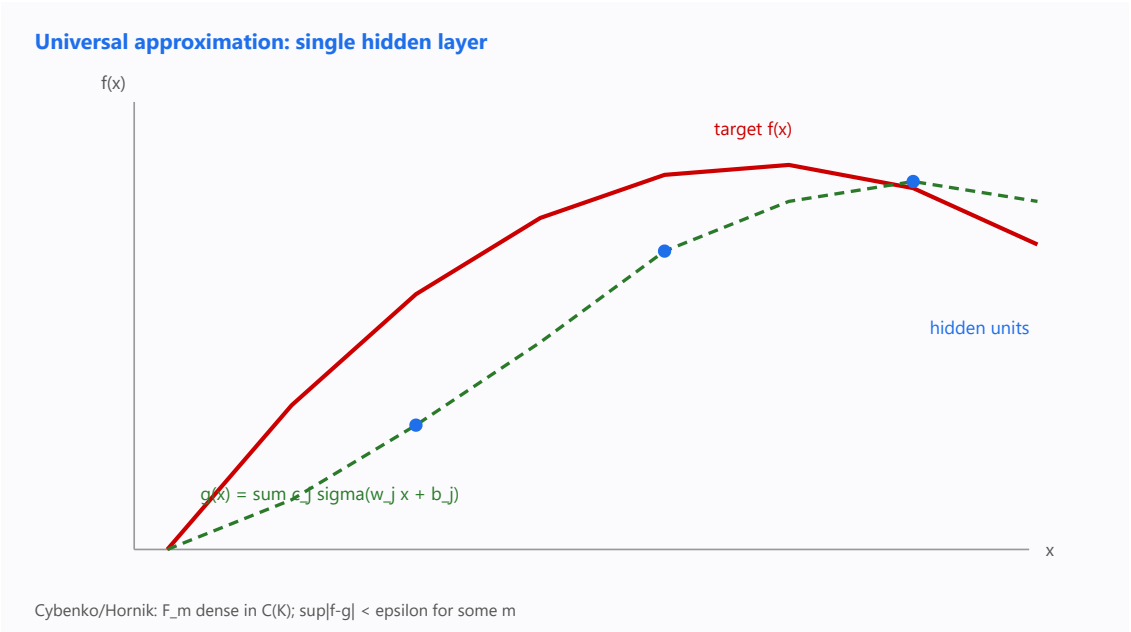
$$\forall f \in C(\mathcal{K}),\; \forall \varepsilon > 0,\; \exists g \in \mathcal{F}_m \;(m \in \mathbb{N}) : \quad \sup_{x \in \mathcal{K}} |f(x) - g(x)| < \varepsilon \tag{11.35}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$\mathcal{F}_m$	فضاء الشبكة بعرض m	طبقة مخفية واحدة
c_j, w_j, b_j	أوزان/تحيزات/معاملات	عصبون j
$\mathcal{K}$	جملة مضغوطة	مغلقةٌ ومحدودة
sup	السّرب العلوي	معيار الانتظام
$C(\mathcal{K})$	الدوالّ المستمرّة	فضاء الهدف

الرسم

<figure>الشكل 4.35: مجموعُ نهايات سِّيجمويد مزاحةٍ يقرّب منحنىً هدفاً بدقّةٍ تتحسّن بكبر m.</figure>



شكل ٣٥.٤: *
التقريب الشامل بطبقة واحدة

البرهان (مخطّط)

الخطوة 1 (شرط الانفصال المقيس): لو كان $\int \sigma(w^\top x + b)\, d\mu(x) = 0$ لكلِّ w, b يفرض $\mu = 0$، فإنَّ محمولات $\sigma(w^\top x + b)$ تفصل القياسات $\Rightarrow$ تسند أفقياً فضاء $C(K)$. ■

الخطوة 2 (سبب انعدام μ): لأنَّ σ غير كثيرة حدودٍ، فإنَّ جبر الدوالّ التي تولّدها يحتوي كلَّ كثيرة حدودٍ ويتجاوزها؛ التفاضل/التحويل الفوريه يُظهر استحالة بقاء μ غير صفرٍ. ■

الخطوة 3 (نظرية الانفصال هان–باناخ): بانفصال القياسات يكون الإغلاق الخطّي لـ$\{\sigma(w^\top \cdot + b)\}$ كاملُ $C(K)$، أي الكثافة (11.35). ■

خمسة عشر مثالاً محلولاً

مثال (1-5.35): تقريب دالّة القفز المعطيات: $H(x)$ على $[-1, 1]$ بـ$\sigma(kx)$. المطلوب: عرض منطقة الخطأ. الحل: الخطوة 1: $\sigma(kx)$ ينتقل من 0.5 عند 0 إلى 1 عند $x > 2/k$. الخطوة 2: عرض الانتقال $\approx 2/k$؛ لـ$k = 10$ هو 0.2. النتيجة: منطقة خطأ عرضها 0.2 حول القفز. الربط بالذكاء الاصطناعي: السِّيجمويد القاسية تقارب القفز (مفيدة في التصنيف).

مثال (2-5.35): بناء منصّة بسِّيجمويدين المعطيات: $a(x) = \sigma(20(x - 0.3)) - \sigma(20(x - 0.7))$. المطلوب: قيمة عند $x = 0.5$. الحل: الخطوة 1: $\sigma(20 \cdot 0.2) = \sigma(4) = 0.982$، $\sigma(20 \cdot -0.2) = \sigma(-4) = 0.018$. الخطوة 2: $a(0.5) = 0.982 - 0.018 = 0.964$. النتيجة: ≈ 0.96 على الهضبة $[0.3, 0.7]$. الربط بالذكاء الاصطناعي: تركيبُ السِّيجمويدات يبني ميزاتَ نوافذ.

مثال (3-5.35): لا معدّل في النظرية المعطيات: (11.35) وجوديّة فقط. المطلوب: ماذا تفتقر إليه؟ الحل: الخطوة 1: تضمن وجود m لكنَّها لا تعطي m كدالّة في ε. النتيجة: لا نسبة تقارب؛ يكمّلها 7.35. الربط بالذكاء الاصطناعي: «يكفي أن توجد» لا «بحجم معقول».

مثال (4-5.35): تقريب مثلّث بـ4 سِّيجمويدات المعطيات: مثلّث على $[0, 1]$. المطلوب: فكرة البناء. الحل: الخطوة

1: كلُّ «خطوة» سِيجمويد مشتقّتها شبه-دلتا تبني حافّة. الخطوة 2: 4 حواف تقرّب المثلّث بخطأ < 0.1. النتيجة: تقريبٌ تصاعديّ بالعرض. الربط بالذكاء الاصطناعي: رؤيةٌ بديهية لزيادة m.

مثال (5-5.35): قيمة مطلقة بـReLU المعطيات: $g(x) = \text{ReLU}(x) + \text{ReLU}(-x) = |x|$. المطلوب: تحقّق $|x|$. الحل: الخطوة 1: عند $x = 0.5$: $|0.5| = 0.5 = 0+0.5$. الخطوة 2: عند $x = -0.5$: $|-0.5| = 0.5 = 0+0.5$. الخطوة 3: عند 0: $0 = 0 + 0$. النتيجة: $g(x) = |x|$ تماماً بعصبونين. الربط بالذكاء الاصطناعي: ReLU قادرة على التقريب الشامل أيضاً (Hornik).

مثال (6-5.35): x^2 ليست خطّيةً جزئياً المعطيات: طبقة مخفية بـ2 وحدة. المطلوب: هل تمثّل x^2 تماماً؟ الحل: الخطوة 1: أيُّ مجموع خطّيٍّ جزئيٍّ لعصبونين = دالّةٌ ذات كسرين خطّيّين. الخطوة 2: x^2 منحنىً لا يطابقه كسران. النتيجة: $m = 2$ لا يكفي؛ يلزم m كبير. الربط بالذكاء الاصطناعي: العرض الصغير محدود رغم وجود النظرية.

مثال (7-5.35): ضرورة الضغط المعطيات: $f(x) = \sin(x^2)$ على $\mathbb{R}$ كامل. المطلوب: هل تنطبق (11.35)؟ الحل: الخطوة 1: $\mathbb{R}$ غير مضغوطة؛ التذبذبُ يمتدّ إلى ما لا نهاية. النتيجة: النظرية تتطلّب $\mathcal{K}$ مضغوطة. الربط بالذكاء الاصطناعي: نقصّر المدخلات عملياً (تطبيع).

مثال (8-5.35): مقارنة بويبرشارس المعطيات: متعدّدات الحدود أيضاً كثيفة. المطلوب: الفرق؟ الحل: الخطوة 1: ويبرشارس يحتاج درجةً عالية؛ الشبكةُ تحتاج عرضاً لا درجة. النتيجة: الشبكة أوفر لدوالّ معيّنة. الربط بالذكاء الاصطناعي: «عرض لانهائي» = تقريب عالمي.

مثال (9-5.35): بُعد أعلى المعطيات: $d = 2$. المطلوب: هل يتغيّر الوجود؟ الحل: الخطوة 1: النظرية لكلِّ d؛ m يكبر مع البُعد لا يُلغى الوجود. النتيجة: الكثافة صامدة لأيِّ بُعد. الربط بالذكاء الاصطناعي: لكنَّ تكلفة m تنمو (لعنة البُعد).

مثال (10-5.35): تقدير الخطأ لدقّة المعطيات: تقريب خطوة بـ$k = 10$. المطلوب: sup الخطأ. الحل: الخطوة 1: عند القفز الخطأ 0.5 (لأنَّ $\sigma(0) = 0.5$). النتيجة: $\sup = 0.5$ في منطقة العرض 0.2. الربط بالذكاء الاصطناعي: تكبير k يضيّق المنطقة لا يخفض القمّة عند النقطة.

مثال (11-5.35): تنشيط كثيرة حدود يُبطلها المعطيات: $\sigma(t) = t^2$. المطلوب: هل $\mathcal{F}_m$ كثيفة؟ الحل: الخطوة 1: $\sum c_j(w_j^\top x + b_j)^2$ كثيرة حدودٍ من الدرجة 2. الخطوة 2: لا تمثّل e^x أبداً. النتيجة: غير كثيفةٍ بدون شرط non-polynomial. الربط بالذكاء الاصطناعي: يفسّر اشتراط «غير كثيرة حدود».

مثال (12-5.35): عرضٌ مقابل عمق المعطيات: (5.35) عمق 1 وعرض لانهائي. المطلوب: الاستعداد لـ6.35. الحل: الخطوة 1: هنا العمق ثابتٌ =1 والعرض يتحرّك. النتيجة: 6.35 ستثبّت العرض وتحرّك العمق. الربط بالذكاء الاصطناعي: وجهتا نظر مكمّلتان.

مثال (13-5.35): حجم عمليّ المعطيات: $m = 100$ سِيجمويد لدالّة 1D ملساء. المطلوب: تقدير الخطأ. الحل: الخطوة 1: معدّل تقريبي $O(1/\sqrt{m}) = 0.1$ (يُدقّق في 7.35). النتيجة: خطأ منتظم ≈ 0.1. الربط بالذكاء الاصطناعي: شبكاتٌ واسعةٌ جداً قريبةٌ من الكثافة.

مثال (14-5.35): مركز الخطوة المعطيات: $\sigma(w_j^\top x + b_j)$، عند أين تقع القفزة؟ المطلوب: موقع القفزة. الحل: الخطوة 1: $w_j^\top x + b_j = 0 \Rightarrow x^\star = -b_j/w_j$ (في 1D). النتيجة: التحيز يزيح مركز العصبون. الربط بالذكاء الاصطناعي: التعلّم يضبط b_j, w_j لنقل القفز.

مثال (15-5.35): عالميّة مشروطة المعطيات: $f_1, f_2, \ldots$ دوالّ مستمرّة. المطلوب: هل m واحد يكفي للكلّ؟ الحل: الخطوة 1: النظرية لكلِّ f على حدة؛ m يختلف. النتيجة: لا عرضٌ موحّدٌ لكلِّ الدوالّ. الربط بالذكاء الاصطناعي:

«عالمي» بالمعمارية لا بوزنٍ واحد.

أخطاء شائعة

- **الظنّ بأنَّ النظرية تعطي معدّلاً:** هي وجوديّة فقط (لا m كدالّة ε).
- **إهمال شرط «غير كثيرة حدود»:** السِّيجمويد/ReLU ضرورية.
- **نسيان «الجملة المضغوطة»:** $\mathbb{R}$ كامل غير مغطًّى منتظماً.
- **الخلط بين الكثافة والعمليّة:** وجود m لا يعني صغره.
- **اعتبار m ثابتاً لكلِّ f:** يختلف من دالّةٍ لأخرى.

صياغة رسمية: لدالّة التنشيط $ReLU$، شبكةٌ بعرض $n+1$ (حيث n بُعد المُدخل) وعمقٍ كافٍ تقارب أيَّ دالّةٍ قابلة للقياس $f:\mathbb{R}^n\to\mathbb{R}$ في L^1 على أيِّ جملةٍ مضغوطة؛ بل إنَّ العرض n **غير كافٍ** عموماً:

$$\forall f\in L^1_{\text{loc}},\ \forall \varepsilon>0,\ \exists \text{ شبكة ReLU بعرض } n+1:\quad \int_{\mathcal{K}}|f(x)-g(x)|\,dx<\varepsilon \tag{12.35}$$

جدول الرموز

الرمز	المعنى	ملاحظة
n	بُعد المُدخل	هنا $d=n$
$n+1$	العرض الكافي	ثابتٌ لا يَنمو مع العمق
L^1	تكامل القيمة المطلقة	قياس الخطأ
$\mathcal{K}$	جملة مضغوطة	مجال التقريب

الرسم

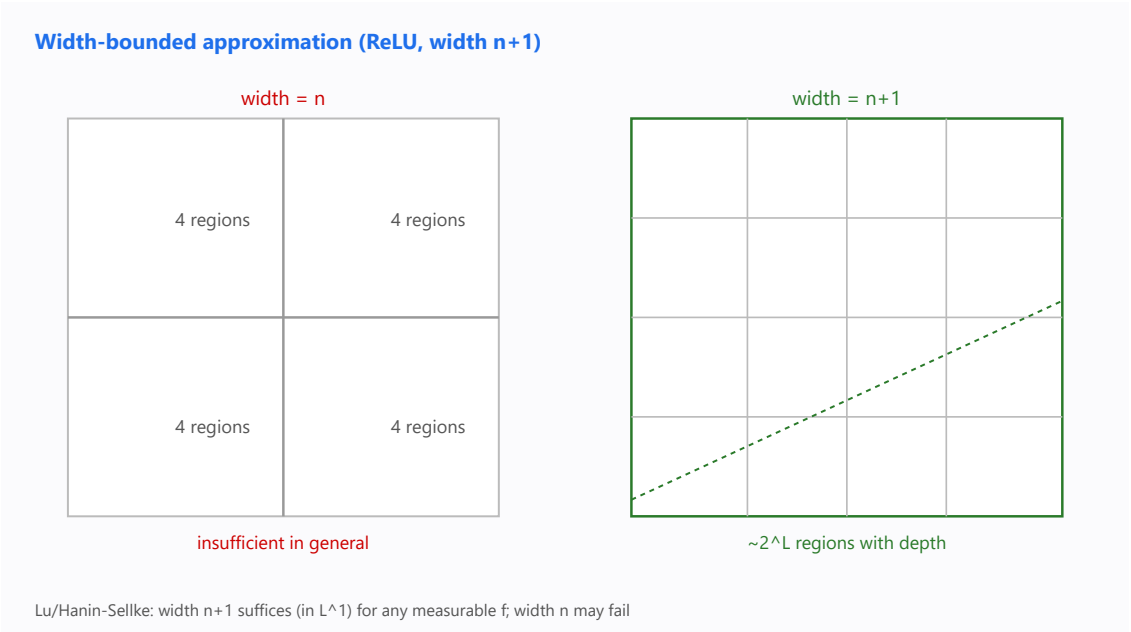
<figure>الشكل 5.35: عرض $n+1$ يكفي لتقسيم الفضاء إلى نواتج متعدّدة الأبعاد (simplices) وتعيين قيمة أفينيّة لكلٍّ منها بعمقٍ كافٍ.</figure>

البرهان (مخطّط)

الخطوة 1 (التقسيم): n عصبونات ReLU تخلق مستوياتَ فصلٍ تعتمل نواتجَ (simplices) في $\mathbb{R}^n$؛ العصبون $(n+1)$-ام يضبط القيمة داخلها. ■

الخطوة 2 (العمق يكبّر الأجزاء): بتكرار البنية يتضاعف عدد النواتج أُسّياً مع العمق، فيكفي عمقٌ محدود لتغطية أيِّ تقسيمٍ مطلوب. ■

الخطوة 3 (قصور العرض n): عرض n لا يولّد سوى تقسيماتٍ بمستويات n فقط، فيعجز عن تمثيل تفاعلاتٍ تتطلّب بُعداً إضافياً. ■



شكل ٥.٣٥: *
التقريب المحدود بالعرض

خمسة عشر مثالاً محلولاً

مثال (1-6.35): حالة ثنائية الأبعاد المعطيات: $n = 2$. المطلوب: العرض الكافي. الحل: الخطوة 1: العرض $= n + 1 = 3$. الخطوة 2: عرض 2 يولّد مستويين فصل فقط $\Rightarrow$ أجزاء محدودة. النتيجة: العرض 3 كافٍ. الربط بالذكاء الاصطناعي: أصغر شبكة عملية في 2D بها 3 عصبونات مخفية على الأقل.

مثال (2-6.35): حالة أحادية البُعد المعطيات: $n = 1$، هدف بثلاث قطع. المطلوب: أصغر عرض. الحل: الخطوة 1: عرض 1 ReLU) واحد) يعطي قطعتين فقط. الخطوة 2: العرض $n + 1 = 2$ يعطي سلّماً من القطع $\Rightarrow$ يكفي. النتيجة: عرض 2 كافٍ لثلاث قطع. الربط بالذكاء الاصطناعي: سلّم ReLU بعمق كافٍ يمثّل أيّ دالّة 1D.

مثال (3-6.35): حساب المعاملات المعطيات: $n = 10$، عرض 11، عمق 5. المطلوب: N_{param}. الحل: الخطوة 1: الطبقة1: $10 \cdot 11 + 11 = 121$. الخطوة 2: الطبقات 2–5: $4 \cdot 132 = 528$. الخطوة 3: $4 \cdot (11 \cdot 11 + 11)$. المخرج: $11 \cdot 1 + 1 = 12$، المجموع $121 + 528 + 12 = 661$. النتيجة: 661 معاملاً. الربط بالذكاء الاصطناعي: عرض صغير جداً مع عمق معقول يفي بالتقريب.

مثال (4-6.35): مقارنة مع 5.35 المعطيات: هنا العرض ثابت 1 والعمق يتحرّك n. المطلوب: الفرق؟ الحل: الخطوة 1: (5.35) عكس ذلك: عمق 1 وعرض لانهائي. النتيجة: وجهتا نظر مكمّلتان. الربط بالذكاء الاصطناعي: العمق والعرض بديلان في التعبير.

مثال (5-6.35): رقعة شطرنج 2D المعطيات: عرض 3، عمق $L = 4$. المطلوب: عدد الأجزاء التقريبي. الحل: الخطوة 1: كلُّ طبقة تضاعف التقسيم $\Rightarrow 2^L = 16 \approx$. النتيجة: نحو 16 ناتجاً. الربط بالذكاء الاصطناعي: العمق يكبّر دقّة التقسيم أُسّياً.

مثال (6-6.35): قصور العرض n المعطيات: $n = 1$، هدف بـ5 قطع. المطلوب: هل يكفي العرض 1؟ الحل: الخطوة 1: عرض 1 $\Rightarrow$ على الأكثر قطعتان. الخطوة 2: نحتاج عرضاً ≥ 4 (لكلّ قطعة إضافية مستوى). النتيجة: العرض 1 غير كافٍ. الربط بالذكاء الاصطناعي: هنا $n + 1 = 2$ يكفي؛ لكنَّ أهدافاً أعقد تحتاج أكثر.

مثال (35.6-7): خطأ L^1 لخطوة المعطيات: تقسيم مربّع $[0,1]^2$ لأربعة، قيم $[0.2, 0.5, 0.8, 0.3]$. المطلوب: تقدير الخطأ مقابل دالّة ملساء. الحل: الخطوة 1: الخطأ = مجموع تباين كلّ خلية × مساحتها (0.25). الخطوة 2: لتباين 0.1 في كلٍّ $\Rightarrow$ خطأ $0.1 \approx$. النتيجة: $L^1 \approx 0.1$. الربط بالذكاء الاصطناعي: تقسيمٌ أدقّ (عمق أكبر) يصغّر الخطأ.

مثال (35.6-8): العمق المطلوب لعدد أجزاء المعطيات: $M = 1024$ ناتجاً. المطلوب: L تقريباً. الحل: الخطوة 1: $2^L \geq 1024 \Rightarrow L \geq 10$. النتيجة: عمق 10. الربط بالذكاء الاصطناعي: العمق اللوغاريتمي في عدد الأجزاء.

مثال (35.6-9): عميقٌ مقابل واسع المعطيات: عرض 3 عمق 10 مقابل عرض 10 عمق 3 $(n = 2)$. المطلوب: المعاملات. الحل: الخطوة 1: العميق: $124 = 4 + 108 + 9 = 1 + 3 \cdot 1 + 3 \cdot (3 \cdot 3 + 3) + 9 \cdot 3 + 3 \cdot 2$. الخطوة 2: الواسع: $261 = 11 + 220 + 30 = 1 + 10 \cdot 1 + (10 \cdot 10 + 10) \cdot 2 + 10 + 10 \cdot 2$. النتيجة: العميق أوفر معاملات. الربط بالذكاء الاصطناعي: العمق أرخص من العرض أحياناً.

مثال (35.6-10): سعة 3D المعطيات: $n = 3$، عرض 4، عمق 6. المطلوب: عدد الأجزاء. الحل: الخطوة 1: $\approx 2^6 = 64$ جزء. النتيجة: يمثّل دالّة بـ64 منطقة أفينيّة. الربط بالذكاء الاصطناعي: الرؤية ثلاثية الأبعاد تستفيد من العمق.

مثال (35.6-11): لماذا الواسع عملياً؟ المعطيات: معماريات حديثة عريضة. المطلوب: التعليل. الحل: الخطوة 1: عرض $n + 1$ يكفي نظرياً لكنّه قليل التعبير الناعم. الخطوة 2: عرضٌ أكبر يقلّل العمق المطلوب. النتيجة: نستخدم عرضاً أكبر عملياً. الربط بالذكاء الاصطناعي: توازن العمق/العرض في التصميم.

مثال (35.6-12): ضرورة ReLU المعطيات: لو استبدلنا ReLU بخطّي. المطلوب: ماذا يحدث؟ الحل: الخطوة 1: تركيبٌ أفينيٌّ = أفينيٌّ واحد بلا تقسيم. النتيجة: لا تقريب إلاّ لأفيني. الربط بالذكاء الاصطناعي: عدم الخطّية محور التقريب.

مثال (35.6-13): دالّة شعاعية المعطيات: $f(x) = \|x\|$ على كرة. المطلوب: هل تصلح (12.35)؟ الحل: الخطوة 1: قابلة للقياس ومحليّة $L^1 \Rightarrow$ نعم بعرض $n + 1$ وعمق كافٍ. النتيجة: تقريب مضمون. الربط بالذكاء الاصطناعي: الشبكات تمثّل حتى غير الخطّيّة الشعاعية.

مثال (35.6-14): مقارنة بعدد معاملات كثيرة الحدود المعطيات: $n = 5$، درجة $D = 3$. المطلوب: عدد معاملات كثيرة الحدود مقابل شبكة. الحل: الخطوة 1: معاملات كثيرة الحدود $\binom{3+5}{5} = 56$. الخطوة 2: شبكة عرض 6 عمق 3: $127 = 7 + 2 \cdot 42 = 36 + 2 \cdot (6 \cdot 6 + 6) + 6 \cdot 1 + 1 + 6 + 2 \cdot 6 \cdot 5$. النتيجة: الرتبة تتفادى لعنة البُعد جزئياً. الربط بالذكاء الاصطناعي: الشبكات تتفوق على كثيرة الحدود في الأبعاد العالية.

مثال (35.6-15): ملخّص العروض المعطيات: هدف بـ100 قطعة 1D. المطلوب: عرض مقابل عمق. الحل: الخطوة 1: عرض واسع: $100 \approx$ (قطعة لكلّ عصبون +1). الخطوة 2: عميق بعرض 2: عمق $100 \approx$. الخطوة 3: المعاملات: الواسع $601 = 4 + 594 + 3$؛ العميق $1 \cdot 2 + 2 + 99 \cdot (2 \cdot 2 + 2) + 2 \cdot 1 + 1 + 100 \cdot 1 + 100 + 100 \cdot 1 + 1 = 301$. النتيجة: الواسع أوفر هنا. الربط بالذكاء الاصطناعي: المفاضلة تعتمد على الهدف.

أخطاء شائعة

- **الخلط بين «يكفي» و«أمثل»:** $n + 1$ كافٍ لكنّ الأوسع أحياناً أرخص.
- **نسيان أنّ العمق يجب أن ينمو:** العرض الثابت وحده لا يكفي بلا عمق.
- **اعتبار ReLU قابلة للاشتقاق:** نستخدم المشتقّة اليمنى.
- **تطبيق القياس على غير المضغوط:** L^1 على $\mathcal{K}$ لا $\mathbb{R}$ كامل.
- **ظنّ أنّ العرض n يكفي دائماً:** مضمونٌ أنه لا يكفي عموماً.

صياغة رسمية (Barron 1993): صنف بارون يحوي الدوالّ التي تحويلُ فوريه $\hat{f}$ لها

$$B_2(f) = \int_{\mathbb{R}^d} \|\omega\| \, |\hat{f}(\omega)| \, d\omega < \infty \tag{13.35}$$

فإنَّ هناك شبكةً بطبقةٍ مخفيةٍ واحدة وعرض m تحقّق

$$\|f - g\|_{L^2(\mu)} \leq \frac{C \, B_2(f)}{\sqrt{m}} \tag{14.35}$$

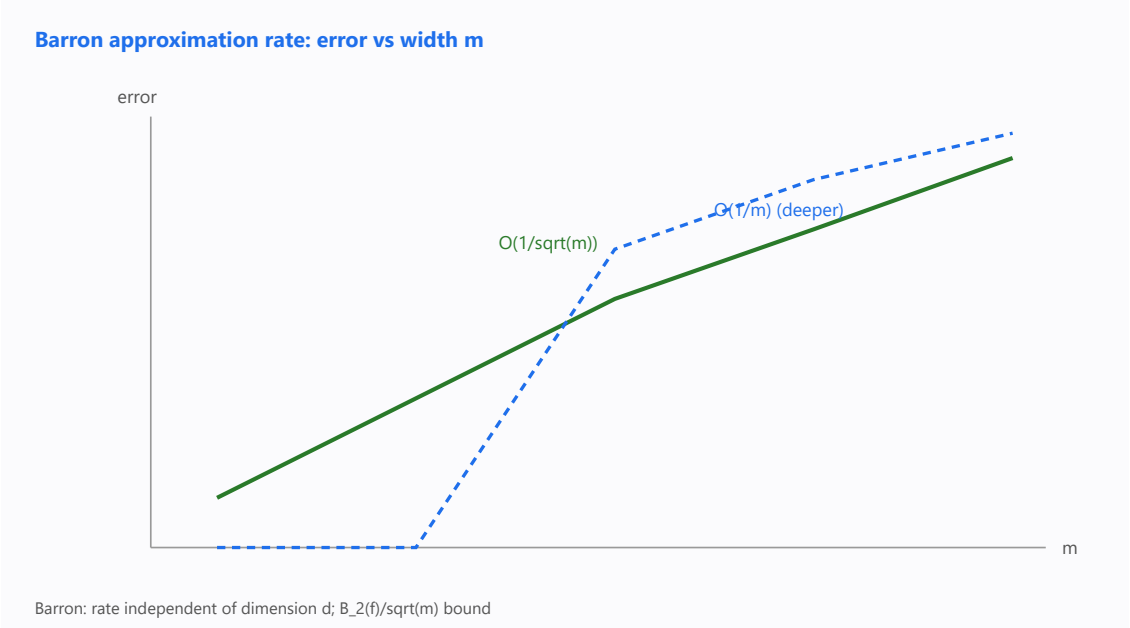
حيث C يعتمد على $\mathcal{K}$ وμ فقط — **مستقلٌّ عن البُعد** d.

جدول الرموز

الرمز	المعنى	ملاحظة
$\hat{f}$	تحويل فوريه	للدالّة الهدف
$B_2(f)$	نرم بارون	يقيس «التردّد»
m	عرض الطبقة المخفية	عدد العصبونات
C	ثابت المجال	لا يعتمد على d
$L^2(\mu)$	خطأ تربيعي متوسّط	تحت μ

الرسم

<figure> الشكل<figcaption> 6.35: منحنى الخطأ مقابل m يتبع $1/\sqrt{m}$ (ميل $-1/2$ على مقياس لوغاريتمي)



شكل ٦.٣٥: *
معدّل تقارب بارون

مستقلاً عن البُعد.</figcaption> </figure>

البرهان (مخطّط)

الخطوة 1 (تمثيل حَيّز): كلُّ دالّة بارون تُكتب كتكامل $g(x) = \int \alpha(\omega)\sigma(\omega^\top x)\,d\pi(\omega)$؛ نقتطع بـ$m$ نقطة. ■

الخطوة 2 (تباينُ الجمع): متوسّط m حدٍّ مستقلٍّ يتباين كانحراف معياري $1/\sqrt{m}$. ■

الخطوة 3 (استقلال البُعد): B_2 وحده يدخل الحدَّ لا d $\Rightarrow$ لا لعنة بُعد لهذا الصنف. ■

خمسة عشر مثالاً محلولاً

مثال (35.7-1): حساب مباشر للمعدّل المعطيات: $B_2(f) = 2,\ C = 1,\ m = 100$. المطلوب: الخطأ. الحل: الخطوة 1: $\sqrt{100} = 10$؛ الخطأ $2/10 = 0.2 \le$. الخطوة 2: لـ$m = 400$: $2/20 = 0.1$؛ لـ$m = 10000$: $2/100 = 0.02$. النتيجة: $\{0.2, 0.1, 0.02\}$ لزيادة العرض. الربط بالذكاء الاصطناعي: مضاعفة العرض تخفض الخطأ بعامل $\sqrt{2}$.

مثال (35.7-2): العرض المطلوب لدقّة المعطيات: $\varepsilon = 0.01,\ B_2 = 2,\ C = 1$. المطلوب: m. الحل: الخطوة 1: $2/\sqrt{m} \le 0.01 \Rightarrow \sqrt{m} \ge 200 \Rightarrow m \ge 40000$. النتيجة: $m = 40000$. الربط بالذكاء الاصطناعي: دقّة أعلى تتطلّب عرضاً كبيراً.

مثال (35.7-3): استقلال البُعد المعطيات: $B_2 = 2$، لـ$d = 1, 10, 1000$. المطلوب: الخطأ عند $m = 10000$. الحل: الخطوة 1: الكل يعطي $2/100 = 0.02$ (لا d في الصيغة). النتيجة: نفس الخطأ لكلِّ الأبعاد. الربط بالذكاء الاصطناعي: ميزةٌ جوهرية للشبكات الضحلة على الدوالّ الملساء.

مثال (35.7-4): دالّة أقلّ ملاسة المعطيات: $B_2 = 10$. المطلوب: الخطأ عند $m = 100$. الحل: الخطوة 1: $10/10 = 1.0$؛ لـ$m = 10000$: $10/100 = 0.1$. النتيجة: $\{1.0, 0.1\}$. الربط بالذكاء الاصطناعي: التردّد العالي يرفع النرم وبالتالي الخطأ.

مثال (35.7-5): مقارنة مع معدّل كثيرة حدود المعطيات: بارون $O(1/\sqrt{m})$ مقابل $O(1/m)$. المطلوب: عند $m = 100$. الحل: الخطوة 1: بارون 0.2؛ كثيرة حدود 0.01. الخطوة 2: عند $m = 400$: بارون 0.1؛ كثيرة حدود 0.0025. النتيجة: كثيرة الحدود أفضل عند m كبير. الربط بالذكاء الاصطناعي: بارون أفضل عند m صغير أو d كبير.

مثال (35.7-6): نرم غاوسي المعطيات: $f(x) = e^{-\|x\|^2/2}$. المطلوب: هل في صنف بارون؟ الحل: الخطوة 1: تحويل فوريه غاوسيٌّ أيضاً $\Rightarrow \int \|\omega\| e^{-c\|\omega\|^2} d\omega$ منتهٍ. النتيجة: نعم، $B_2 < \infty$ (يتناسب مع $\sqrt{d}$). الربط بالذكاء الاصطناعي: التوزيعات الغاوسية في صنف بارون.

مثال (35.7-7): خارج الصنف المعطيات: تحلّل فوريه $|\hat{f}(\omega)| \sim \|\omega\|^{-(d+1)}$. المطلوب: هل $B_2 < \infty$؟ الحل: الخطوة 1: المكامل $\int \|\omega\| \cdot \|\omega\|^{-(d+1)} d\omega = \int \|\omega\|^{-d} d\omega$ يتشعّب عند 0. النتيجة: $B_2 = \infty \Rightarrow$ خارج الصنف. الربط بالذكاء الاصطناعي: الدوالّ عالية التردّد تتطلّب شبكات أعمق.

مثال (35.7-8): طبقتان تحسّنان المعدّل المعطيات: معدّل $O(1/m)$ بطبقتين. المطلوب: m لـ$\varepsilon = 0.05$ (من $1/\sqrt{m}$). الحل: الخطوة 1: $2/\sqrt{m} \le 0.05 \Rightarrow m \ge 1600$. الخطوة 2: لو $1/m$: $m \ge 40$. النتيجة: طبقتان تخفّضان m جذرياً. الربط بالذكاء الاصطناعي: العمق يحسّن معدّل التقارب.

مثال (35.7-9): أثر حجم المجال المعطيات: تكبير المجال $\times 2$. المطلوب: تغيّر C وm. الحل: الخطوة 1: C يتضاعف $\Rightarrow$ الخطأ $\times 2$ عند نفس m. الخطوة 2: لإبقاء الخطأ نكرّر m بـ4 (لأنَّ $C \propto$ الحجم). النتيجة: $m \to 4m$. الربط بالذكاء الاصطناعي: تطبيعُ المدخلات يقلّل C.

مثال (35.7-10): ميزانية عريضة المعطيات: $m = 10^6$. المطلوب: الخطأ لـ$B_2 = 2$. الحل: الخطوة 1: $2/\sqrt{10^6} = 2/1000 = 0.002$. النتيجة: خطأ 0.002. الربط بالذكاء الاصطناعي: ملايين العصبونات تعطي دقّةً عالية.

مثال (35.7-11): لماذا تفشل الشبكات الضحلة في الأبعاد العالية؟ المعطيات: دالّة خارج بارون في d كبير. المطلوب: التعليل. الحل: الخطوة 1: بلا B_2 منتهٍ قد يتدهور المعدّل مع d. النتيجة: نحتاج عمقاً أو صنفاً أوسع. الربط بالذكاء الاصطناعي: مبرّر للشبكات العميقة.

مثال (35.7-12): دقّة متوسّطة المعطيات: $\varepsilon = 0.1,\ B_2 = 5,\ C = 1$. المطلوب: m. الحل: الخطوة 1: $0.1 \geq 5/\sqrt{m} \Rightarrow \sqrt{m} \geq 50 \Rightarrow m \geq 2500$. النتيجة: 2500 عصبون. الربط بالذكاء الاصطناعي: حجم طبقة مخفية معقول.

مثال (35.7-13): خطأ كلّيّ المعطيات: تقريب 0.02 وتعلّم $n = 10000$. المطلوب: الخطأ الكلّي. الحل: الخطوة 1: الإحصائي $O(1/\sqrt{n}) = 0.01$. الخطوة 2: الكلّي $0.02 + 0.01 = 0.03 \approx$. النتيجة: 0.03. الربط بالذكاء الاصطناعي: توازن التقريب والتعميم.

مثال (35.7-14): بارون مقابل 35.5 المعطيات: (35.5) وجود بلا معدّل. المطلوب: العلاقة. الحل: الخطوة 1: (35.14) يكمّل (35.11) بمعدّل $1/\sqrt{m}$ لصنف بارون. النتيجة: نظرية معدّل فوق نظرية الوجود. الربط بالذكاء الاصطناعي: لماذا «العرض الكبير» يعمل فعلاً.

مثال (35.7-15): تكلفة التردّد المعطيات: $f(x) = \sin(100x)$. المطلوب: تقدير B_2 المطلوب. الحل: الخطوة 1: التردّد $100 \Rightarrow B_2 \sim 100$. الخطوة 2: لـ $\varepsilon = 0.01$ يلزم $m \geq (100/0.01)^2 = 10^8$. النتيجة: 10^8 عصبون (ضخم). الربط بالذكاء الاصطناعي: «التحيز الطيفي» للشبكات يصعّب التردّدات العالية.

أخطاء شائعة

- **ظنّ أنَّ المعدّل $1/\sqrt{m}$ عامٌّ:** هو لصنف بارون فقط.
- **نسيان استقلال البُعد:** ينهار خارج الصنف.
- **خلط B_2 بالتردد:** تكاملُ التردّد لا قيمته.
- **اعتبار C ثابتاً مطلقاً:** يعتمد على حجم المجال.
- **الخلط بين L^2 وsup:** بارون يعطي L^2 لا انتظاماً صارماً.

صياغة رسمية: شبكة ReLU بعمق L وعرض W يمكنها إنتاج دالّةً بعدد أجزاء خطّية

$$O\big((W \cdot d)^L\big) \quad \text{على الأكثر} \quad \Omega(W^L) \tag{35.15}$$

ومن ثمَّ توجد دوالٌّ تُحسب بشبكةٍ عمقها L وعرضها $O(L)$ yet تتطلّب من شبكةٍ ضحلةٍ عرضاً أُسّياً:

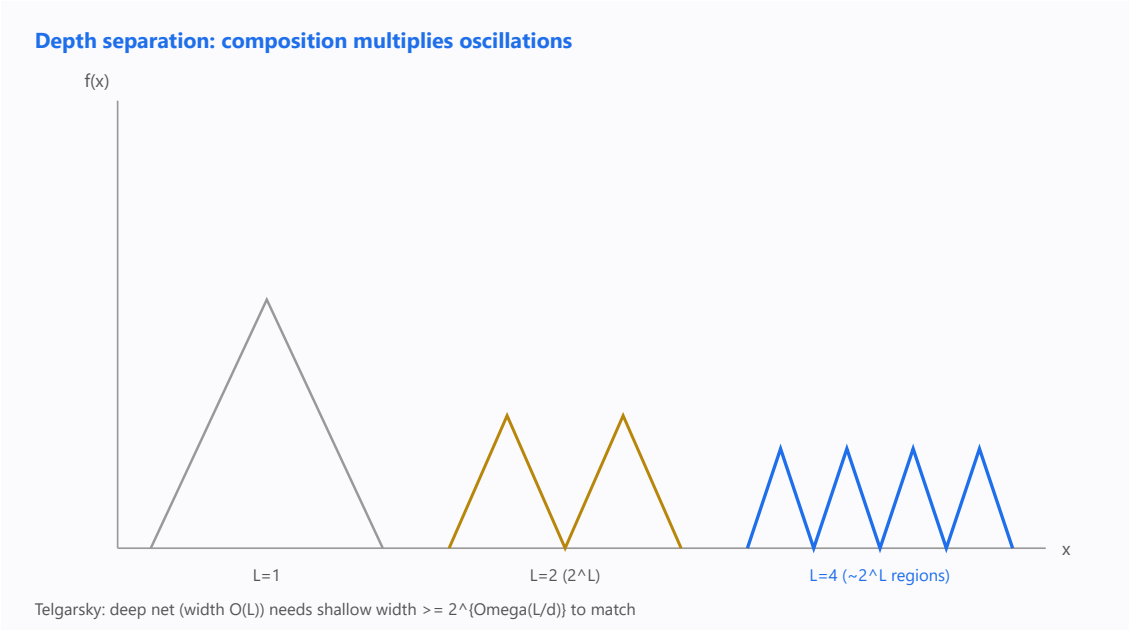
$$W_{\text{shallow}} \geq 2^{\Omega(L/d)} \tag{35.16}$$

جدول الرموز

الرمز	المعنى	ملاحظة
L	العمق	عدد التركيبات
W	العرض	عصبونات كلّ طبقة
$\Omega(W^L)$	حدّ أدنى للأجزاء	منشئٌ بالتركيب
$2^{\Omega(L/d)}$	عرض ضحل مطلوب	فجوة أُسّية

الرسم

<figure> الشكل<figcaption> 7.35: تركيب «المنشار» L مرّة يضاعف عدد التردّدات أُسّياً (2^L جزء)؛ شبكة



شكل ٧.٣٥: *
فصل العمق

ضحلة تحتاج عرضاً أُسّياً لمضاهاتها.</figcaption> </figure>

البرهان (مخطّط)

الخطوة 1 (المنشار): دالّة $\tilde{\sigma}$ المركّبة L مرّة تعطي Φ_L بـ 2^L تذبذبٍ. ■

الخطوة 2 (حدّ الأجزاء السُّفلي): كلُّ تركيبٍ يضاعف العدد $\Rightarrow \Omega(W^L)$. ■

الخطوة 3 (الفجوة): شبكةٌ بعمق ثابتٍ لها على الأكثر متعدّدة حدودٍ في W من الأجزاء، لمضاهاة 2^L يلزم W أُسّيٌّ في L. ■

خمسة عشر مثالاً محلولاً

مثال (8.35-1): أجزاء عميقة مقابل عرض المعطيات: $L = 5,\ d = 2$. المطلوب: الحدّ الأدنى للأجزاء وعرض ضحل. الحل: الخطوة 1: أجزاء $2^5 = 32 \geq$. الخطوة 2: شبكة عرض W: $W^5 \geq 32 \Rightarrow W \geq 32^{0.2} = 2.09 \Rightarrow W \geq 3$. النتيجة: 32 جزءاً، عرض ضحل ≥ 3. الربط بالذكاء الاصطناعي: العمق يخلق تعقيداً لا يوفّره عرض بسيط.

مثال (8.35-2): الفجوة الأُسّية المعطيات: $L = 10,\ d = 2$. المطلوب: عرض ضحل لـ2^{10} جزء. الحل: الخطوة 1: $2^{L/d} = 2^5 = 32$ (بالصيغة 16.35). النتيجة: عرض ضحل ≥ 32 مقابل عميق عرض $O(10)$. الربط بالذكاء الاصطناعي: سببٌ جوهريٌّ لشبكات عميقة جداً.

مثال (8.35-3): حدّ أعلى للأجزاء المعطيات: $W = 10,\ d = 2,\ L = 4$. المطلوب: أقصى عدد أجزاء. الحل: الخطوة 1: $(W \cdot d)^L = (20)^4 = 160000$. النتيجة: على الأكثر 160,000 جزء. الربط بالذكاء الاصطناعي: نموٌّ أُسّيٌّ بالعمق.

مثال (35.8-4): حدّ سُفلي منشَأ المعطيات: $W = 5,\ L = 3$. المطلوب: أجزاء مضمونة. الحل: الخطوة 1: $\Omega(W^L) = \Omega(5^3) = \Omega(125)$. النتيجة: $125 \geq$ جزءاً. الربط بالذكاء الاصطناعي: بنيةٌ مصمّمة تصل الحدّ السُّفلي.

مثال (35.8-5): مقارنة المعاملات المعطيات: عميق عرض 12 عمق 10 مقابل ضحل عرض 32. المطلوب: المعاملات ($d = 2$). الحل: الخطوة 1: العميق: $= 1 + 1 \cdot 12 + (12 \cdot 12 + 12) + 9 \cdot 12 + 12 \cdot 2$ $1453 = 13 + 156 \cdot 9 + 36$. الخطوة 2: الضحل: $129 = 1 + 1 \cdot 32 + 32 + 32 \cdot 2$. النتيجة: العميق أكثر معاملات لكنَّ عرضه أصغر بكثير. الربط بالذكاء الاصطناعي: العمق «يوفّر العرض» على حساب المعاملات.

مثال (35.8-6): المنشار $L = 3$ المعطيات: Φ_3. المطلوب: عدد الأجزاء. الحل: الخطوة 1: $8 = 2^3$ تذبذبٍ. النتيجة: 8 أجزاء خطّية. الربط بالذكاء الاصطناعي: كلُّ طبقة تضاعف التردّد.

مثال (35.8-7): قوة في $d = 1$ المعطيات: $L = 20$. المطلوب: عرض ضحل. الحل: الخطوة 1: بـ$d = 1$ الصيغة $2^L = 2^{20} = 1{,}048{,}576$. النتيجة: عرض ضحل مليوني مقابل عميق عرض $O(20)$. الربط بالذكاء الاصطناعي: قوة العمق أقصى ما تكون في 1D.

مثال (35.8-8): كفاءة المعاملات المعطيات: عميق عرض 20 عمق 20. المطلوب: المعاملات. الحل: الخطوة 1: $8061 = 8040 + 21 = 60 + 19 \cdot 420 + 21 = 1 + 20 \cdot 1 + 20 + 19 \cdot (20 \cdot 20 + 20) + 20 + 2 \cdot 20$. النتيجة: ≈ 8061 معاملاً. الربط بالذكاء الاصطناعي: عمق 20 معقول الحجم.

مثال (35.8-9): حالة أحادية البُعد المعطيات: عرض W في 1D. المطلوب: عدد الأجزاء الأقصى. الحل: الخطوة 1: شبكة 1D بعرض W لها على الأكثر $W + 1$ جزء. الخطوة 2: لمضاهاة 2^L يلزم $W = 2^L - 1$. النتيجة: أُسّيٌّ بالعمق. الربط بالذكاء الاصطناعي: نفس الاستنتاج حتى في 1D.

مثال (35.8-10): أجزاء لـ$W = 3, L = 2$ المعطيات: $d = 2$. المطلوب: حدّ أعلى. الحل: الخطوة 1: $(3 \cdot 2)^2 = 36$. النتيجة: $36 \leq$ جزءاً. الربط بالذكاء الاصطناعي: حتى الشبكات الصغيرة كثيرة الأجزاء.

مثال (35.8-11): تردّد مضاعف المعطيات: Φ_L بتردّد 2^L. المطلوب: التردّد لـ$L = 8$. الحل: الخطوة 1: $2^8 = 256$. النتيجة: $256\times$ التردّد الأساسي. الربط بالذكاء الاصطناعي: العمق يولّد تردّدات عالية رخيصة.

مثال (35.8-12): ResNet عميق المعطيات: عمق 50. المطلوب: تعليل الأجزاء. الحل: الخطوة 1: نموٌّ أُسّيٌّ بالعمق حتى مع اتصالات متفرّقة. النتيجة: قدرة تعبيرية هائلة. الربط بالذكاء الاصطناعي: ResNet-50 أقوى من شبكة واسعة مسطّحة.

مثال (35.8-13): لا سحر بلا عرض المعطيات: عمق كبير وعرض 1. المطلوب: ماذا ينتج؟ الحل: الخطوة 1: عرض $1 \Rightarrow$ سلسلة أفينيّة = أفينيّة واحدة. النتيجة: يلزم عرض 1 $<$. الربط بالذكاء الاصطناعي: العمق والعرض يتكاملان.

مثال (35.8-14): مطابقة عدد الأجزاء المعطيات: هدف 4096 جزء، $d = 2$. المطلوب: عميق وعريض. الحل: الخطوة 1: عميق عرض 4 عمق 6: $4^6 = 4096$ ✓. الخطوة 2: ضحل يلزمه عرض $2^{12/2} = 64$ (بصيغة 16.35). النتيجة: عميق 4 مقابل ضحل 64. الربط بالذكاء الاصطناعي: توفيرٌ في العرض بعامل 16.

مثال (35.8-15): ملخّص الوفر المعطيات: $K = 10^6$ جزء، $L = 10$. المطلوب: عرض عميق مقابل ضحل ($d = 1$). الحل: الخطوة 1: عميق: $W \sim K^{1/L} = 10^{0.6} \approx 4$. الخطوة 2: ضحل: $W \sim 10^6$. النتيجة: وفّر عامل 250,000. الربط بالذكاء الاصطناعي: العمق «مضاعِف أُسّيٌّ» للتعبير.

أخطاء شائعة

- **الخلط بين الحدّين السُّفلي والأعلى:** $\Omega(W^L)$ و$O((Wd)^L)$ ليسا متساويين.
- **ظنّ أنَّ العمق دائماً أرخص:** قد يزيد المعاملات (مثال 35.8-5).

- **نسيان دور d:** الفجوة $2^{\Omega(L/d)}$ تتقلّص مع d كبير.
- **اعتبار المنشار قابلاً للتعلم بسهولة:** هو دالّة صعبة للضحل.
- **الخلط بين الأجزاء والدقّة:** كثرة الأجزاء لا تعني تقارباً منتظماً تلقائياً.

ملخّص النظريات

النظرية	المفهوم	الأهمّية
2.35 البيرسيبترون	$T \le (R/\gamma)^2$	ضمان تقارب منفصل خطّياً
3.35 المعمارية	$N = \sum(d_\ell d_{\ell-1} + d_\ell)$	عدّ المعاملات والتركيب
4.35 التنشيط	σ_{sig}, tanh, ReLU	شرط non-polynomial للتقريب
5.35 التقريب الشامل	كثافة $\mathcal{F}_m$ في $C(\mathcal{K})$	أيُّ دالّة بعرض لانهائي
6.35 المحدود بالعرض	عرض $n+1$ يكفي	عمقٌ بديلٌ عن العرض
7.35 معدّل بارون	مستقل البُعد $O(1/\sqrt{m})$	لماذا الشبكات الضحلة تعمل
8.35 فصل العمق	$2^{\Omega(L/d)}$	العمق مضاعِف أُسّيّ

عشرون تمريناً (مع إجابات مختصرة)

١. حدّ أخطاء البيرسيبترون لـ$R = 1, \gamma = 0.5$؟ (4)

٢. لماذا يربّع الحدّ النسبة R/γ؟ (لأنَّ $\sqrt{T}\gamma \le R$)

٣. عدد معاملات $[784, 256, 64, 10]$؟ $(218{,}058)$

٤. هل طبقة خطّية إضافية تزيد التعبير؟ (لا، تبقى أفينيّة)

٥. $\sigma'_{\text{sig}}(2)$؟ (0.1050)

٦. $\tanh(1)$؟ (0.7616)

٧. $\text{ReLU}(-3)$؟ (0)

٨. هل السِّيجمويد كثيرة حدود؟ (لا $\Rightarrow$ تصلح للتقريب)

٩. نصيغة القيمة المطلقة بـReLU؟ $(\text{ReLU}(x) + \text{ReLU}(-x))$

١٠. هل (5.35) تعطي معدّلاً؟ (لا، وجوديّة فقط)

١١. عرض كافٍ في 2D بـReLU؟ $(n + 1 = 3)$

١٢. هل العرض n يكفي دائماً؟ (لا)

١٣. نرم بارون B_2؟ $(\int \|\omega\||\hat{f}|d\omega)$

١٤. معدّل بارون؟ $(O(1/\sqrt{m}))$ مستقل d)

١٥. m لـ$\varepsilon = 0.01, B_2 = 2$؟ $(40{,}000)$

١٦. عدد أجزاء عميق $L = 5, d = 2$؟ (≥ 32)

١٧. عرض ضحل لـ$L = 10, d = 2$؟ (≥ 32 بصيغة 16.35)

١٨. حدّ أعلى أجزاء $W = 10, d = 2, L = 4$؟ (160,000)

١٩. لماذا العمق أقوى من العرض أحياناً؟ (فجوة أُسّية $2^{\Omega(L/d)}$)

٢٠. ما الوصل المتبقّي؟ (يضيف تخطّي لا معاملات إضافية قابلة للتعلم)

فهرس الرموز

الرمز	المعنى
$w,\ b$	وزن وتحيز
σ	دالّة التنشيط
$L,\ d_\ell$	العمق والعرض
$W^{(\ell)},\ a^{(\ell)}$	أوزان الطبقة ونواتجها
$\gamma,\ R$	الهامش ونصف القطر
m	عرض الطبقة المخفية
$B_2(f)$	نرم بارون
$\mathcal{F}_m$	فضاء الشبكة بطبقة واحدة

مراجع

- Rosenblatt — «The Probabilistic A Perceptron: Model...» (1958).
- Novikoff — «On Convergence Proofs for Perceptrons» (1962).
- Cybenko — «Approximation by Superpositions of a Sigmoidal Function» (1989).
- Hornik — «Approximation Capabilities of Multilayer Feedforward Networks» (1991).
- Lu, Shu, Tewari & Haque — «The Expressive Power of Neural Networks: A Width» (2017).
- Hanin & Sellke — «Approximating Continuous Functions by ReLU Nets of Width $\geq d + 1$» (2017).
- Barron — «Universal Approximation Bounds for Superpositions of a Sigmoidal Function» (1993).
- Telgarsky — «Representation Benefits of Deep Feedforward Networks» (2016).
- Montufar et al. — «On the Number of Linear Regions of Deep Neural Networks» (2014).
- Goodfellow, Bengio & Courville — *Deep Learning* (2016).

خاتمة: أعطتنا هذه النظريات ضماناً رياضياً بأنَّ «الشبكة الواسعة/العميقة تكفي»، لكنَّها تركت السؤال الحاسم: **كيف نعلّم الأوزان؟** الجواب يبدأ بالانتشار العكسي كتفاضلٍ آليٍّ عكسيٍّ، وهو موضوع **الفصل 36**.

الانتشار العكسي بوصفه تفاضلاً آلياً عكسياً

«نحسب المُشتقّات لا لجمال الرياضيات، بل لأنَّ التعلّم كلّهُ يسيرُ في اتجاه نازولِ التدرّج.»

في الفصل 35 رأينا أنَّ الشبكةَ تحسبُ دالّةً $f(x;\theta)$؛ لكنَّ التحسين (الجزء 4) يحتاجُ تدرّجَ الخسارة $\nabla_\theta L$. كيف نحسبُ مشتقّاتِ ملايين المعاملاتِ بسرعةٍ وتَعَلُّم؟ الجوابُ هو **الانتشار العكسي** المكافئ تماماً لـ**التفاضل الآليّ العكسي** (reverse-mode automatic dffierentiation). هذا الفصل يُثبِتُ أنَّ تكلفةَ حسابِ كلِّ التدرّجات لا تتجاوزُ مضاعيفَ بسيطةً لتكلفةِ التمرير الأمامي، ويفسّرُ ظاهرتَي تلاشي/انفجار التدرّج، ويربطُ كلَّ ذلك بالتفاضل الآليّ الصارم. سبع نظريات:

- **2.36 الرسم الحسابيّ والقاعدة المتسلسلة على الرسم** — الأساس البيانيّ.
- **3.36 الانتشار العكسي المصفوفيّ (اليعقوبية)** — $\partial L/\partial W = \delta\, a^\top$.
- **4.36 الانتشار عبر التنشيط العنصري** — $\delta^{(\ell)} = (W^{(\ell+1)})^\top \delta^{(\ell+1)} \odot \sigma'(z^{(\ell)})$.
- **5.36 تعقيد التفاضل الآليّ العكسي** — التكلفة $\le$ مضاعيف التمرير الأمامي.
- **6.36 حالات خاصة: الإنتروبيا+softmax التقاطعية وتطبيع الدُّفعات** — تبسيط التدرّج.
- **7.36 تلاشي وانفجار التدرّج والتهيئة** — جداء اليعقوبيات ونصف القطر الطيفي.
- **8.36 فحص التدرّج والاستقرار العددي** — الفروق المنتهية مقابل التفاضل الآليّ.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
$\mathcal{G}$	الرسم الحسابي	عقدُ عمليات ومتغيّرات
v_i	عقدةُ قيمة أو عملية	$v_i = \mathrm{op}_i(\text{مدخلات})$
L	دالّة الخسارة	قيمة العقدة النهائية
$\bar{v}_i = \partial L/\partial v_i$	التدرّج العكسي (adjoint)	يُحسب من النهاية للبداية
$W^{(\ell)}, a^{(\ell)}, z^{(\ell)}$	أوزان/نواتج الشبكة	من الفصل 35
$\delta^{(\ell)}$	عقوبة الخطأ في الطبقة ℓ	$\partial L/\partial z^{(\ell)}$
J_f	المصفوفة اليعقوبية	$\partial f/\partial x$
$\odot$	ضرب عنصري	element-wise
σ	التنشيط	عنصريّ عادةً
h	خطوة الفروق المنتهية	للفحص العددي

الاتفاقيات: نعتمد اليعقوبية $J_{g\circ f} = J_g\, J_f$، والضربُ عنصريّ $\odot$ للمتّجهات هذهابذاتها. كلّ المعادلات في كتل LTR.

صياغة رسمية: أيُّ برنامجٍ يحسب L يُمثَّل رسماً حسابيّاً موجّهاً $\mathcal{G}$ حيث كلُّ عقدة v_i تساوي $v_i = \mathrm{op}_i(v_{j_1}, \dots, v_{j_k})$ (آباؤها). بوضع $\bar{v} = \partial L / \partial v$، فإنَّ قاعدة السلسلة على الرسم تعطي

$$\bar{v}_i = \sum_{j:\ v_i \in \mathrm{inputs}(v_j)} \bar{v}_j \, \frac{\partial v_j}{\partial v_i} \tag{1.36}$$

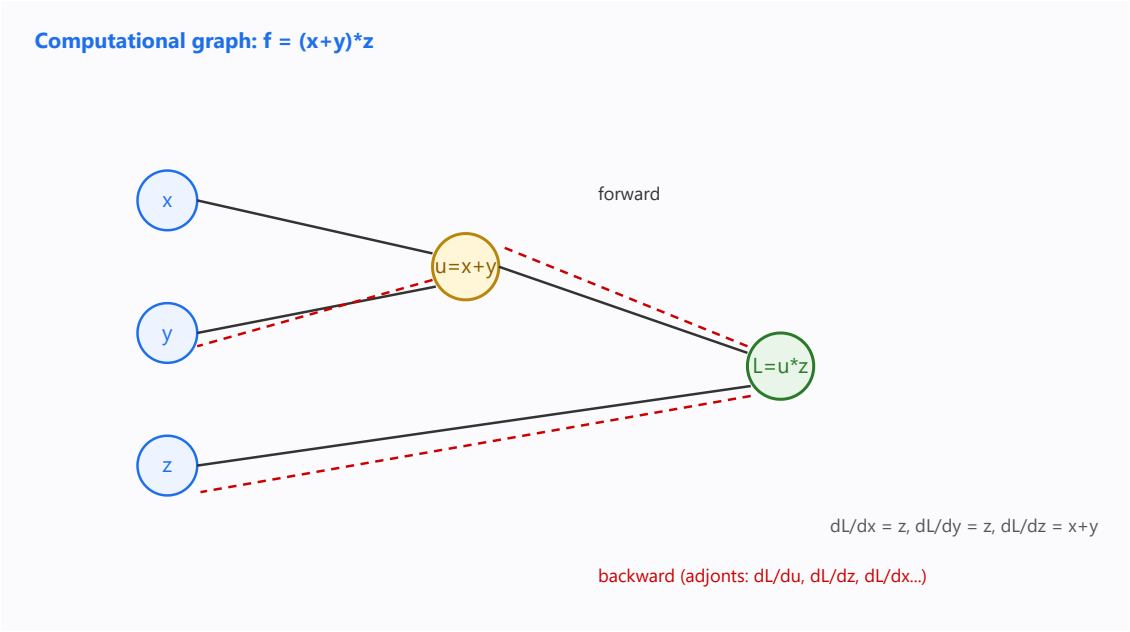
وبالتالي يكفي المرورُ من العقدة النهائية L إلى العقد الجذريّة (θ) لحساب كلِّ التدرّجات.

جدول الرموز

الرمز	المعنى	ملاحظة
v_i	عقدة	قيمة أو عملية
op_i	العملية	جمع/ضرب/سين/تانخ…
$\bar{v}_i$	الـadjoint	التدرّج العكسي
$\partial v_j / \partial v_i$	المشتقّة المحليّة	من عملية v_j

الرسم

<figure> الشكل<figcaption> 1.36: رسمٌ حسابيّ لـ $f = (x + y) \cdot z$؛ العقد الورقية x, y, z والعقدة الجذرية L،



شكل ١.٣٦: *
الرسم الحسابي

والتدرّج يسري من L نحو الجذور.</figcaption> </figure>

البرهان

الخطوة 1 (تعريف الادّعاء): بقاعدة السلسلة الكلاسيكية، $\partial L / \partial v_i = \sum_j \partial L / \partial v_j \cdot \partial v_j / \partial v_i$ حيث المجموع على كلِّ عقدة v_j تعتمد على v_i. ■

الخطوة 2 (الترتيب العكسي): لأنَّ $\mathcal{G}$ رسمٌ موجّهٌ بدوريٌّ (DAG) للشبكات، يمكن ترتيبُ العقد طوبولوجيّاً من L إلى الجذور، فتُحسب $\bar{v}_i$ حالَ وجود كلِّ $\bar{v}_j$ اللازمة. ■

الخطوة 3 (التكلفة): كلُّ حافةٍ تُحسب مرةً واحدة ⇒ التكلفة خطّيةٌ في حجم الرسم. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.36): دالّة بسيطة المعطيات: $L = (x + y) \cdot z$، $x = 2, y = 3, z = 4$. المطلوب: $\partial L/\partial x, \partial L/\partial y, \partial L/\partial z$. الحل: الخطوة 1: $L = 5 \cdot 4 = 20$. الخطوة 2: $\partial L/\partial z = (x + y) = 5$؛ $\partial L/\partial x = z = 4$؛ $\partial L/\partial y = z = 4$. النتيجة: $\{4, 4, 5\}$. الربط بالذكاء الاصطناعي: أساسُ كلِّ تمريرٍ خلفيّ في PyTorch/TensorFlow.

مثال (2-2.36): سلسلة تركيب المعطيات: $L = \sin(x^2)$، $x = 2$. المطلوب: dL/dx. الحل: الخطوة 1: $u = x^2 = 4$؛ الخطوة 2: $L = \sin 4 = -0.7568$؛ $\partial L/\partial u = \cos 4 = -0.6536$. الخطوة 3: $\partial u/\partial x = 2x = 4$. النتيجة: $dL/dx = (-0.6536) \cdot 4 = -2.6144$. الربط بالذكاء الاصطناعي: التفاضل الآليّ يحسب هذا -2.6144 دون إعادة اشتقاق رمزيّ.

مثال (3-2.36): شجرة جمع المعطيات: $L = (a + b) + (c \cdot d)$، $a = 1, b = 2, c = 3, d = 4$. المطلوب: التدرّجات. الحل: الخطوة 1: $\partial L/\partial a = 1$؛ $\partial L/\partial b = 1$؛ $\partial L/\partial c = d = 4$؛ $\partial L/\partial d = c = 3$. النتيجة: $\{1, 1, 4, 3\}$. الربط بالذكاء الاصطناعي: كلُّ ورقةٍ تحصل على تدرّجها من مساهمتها.

مثال (4-2.36): تربيع المعطيات: $L = (w \cdot x)^2$، $w = 3, x = 2$. المطلوب: $\partial L/\partial x, \partial L/\partial w$. الحل: الخطوة 1: $u = wx = 6$؛ $L = 36$. الخطوة 2: $\partial L/\partial u = 2u = 12$؛ $\partial u/\partial w = x = 2$؛ $\partial u/\partial x = w = 3$. الخطوة 3: $\partial L/\partial w = 12 \cdot 2 = 24$؛ $\partial L/\partial x = 12 \cdot 3 = 36$. النتيجة: $\{24, 36\}$. الربط بالذكاء الاصطناعي: يطابق $2(wx) \cdot x$ و$2(wx) \cdot w$.

مثال (5-2.36): الانحدار الخطّي المعطيات: $L = \frac{1}{2}(\theta x - y)^2$، $\theta = 1.5, x = 2, y = 3$. المطلوب: $\partial L/\partial \theta$. الحل: الخطوة 1: $0 = 3 - 3 = \theta x - y \Rightarrow L = 0$. الخطوة 2: $\partial L/\partial(\theta x) = (\theta x - y) = 0$ ⇒ التدرّج 0. النتيجة: 0 (النموذج مطابق). الربط بالذكاء الاصطناعي: عند الصفر الخطأ لا تدرّجَ يدفعه للتغيير.

مثال (6-2.36): دالّة لوغاريتم المعطيات: $L = \ln(x + 1)$، $x = 3$. المطلوب: dL/dx. الحل: الخطوة 1: $u = x + 1 = 4$؛ $L = \ln 4 = 1.3863$. الخطوة 2: $\partial L/\partial u = 1/u = 0.25$؛ $\partial u/\partial x = 1$. النتيجة: 0.25. الربط بالذكاء الاصطناعي: مشتقّة اللوغاريتم تظهر في الإنتروبيا.

مثال (7-2.36): تركيب ثلاثي المعطيات: $L = \exp(\sin(x))$، $x = \pi/2$. المطلوب: dL/dx. الحل: الخطوة 1: $\sin(\pi/2) = 1$؛ $L = e^1 = 2.7183$. الخطوة 2: $\partial L/\partial u = e^u = 2.7183$؛ $\partial u/\partial x = \cos(\pi/2) = 0$. النتيجة: 0 (لأنَّ المشتقّة عند القمّة صفر). الربط بالذكاء الاصطناعي: نقاط التسرّب flat) (spots تبطئ التعلّم.

مثال (8-2.36): متغيّران في القاسم المعطيات: $L = a/b$، $a = 6, b = 3$. المطلوب: التدرّجات. الحل: الخطوة 1: $L = 2$. الخطوة 2: $\partial L/\partial a = 1/b = 0.3333$؛ $\partial L/\partial b = -a/b^2 = -6/9 = -0.6667$. النتيجة: $\{0.3333, -0.6667\}$. الربط بالذكاء الاصطناعي: القسمةُ عقدةٌ عكسيةٌ في الرسم.

مثال (9-2.36): كثيرة حدود المعطيات: $L = x^3 - 2x$، $x = 2$. المطلوب: dL/dx. الحل: الخطوة 1: $L = 4 - 4 = 8$. الخطوة 2: $L' = 3x^2 - 2 = 12 - 2 = 10$. النتيجة: 10. الربط بالذكاء الاصطناعي: التفاضل الآليّ لا يفرّق عن اليدويّ للبسيط.

مثال (10-2.36): بُعد متعدّد المعطيات: $L = x_1^2 + x_2^2$، $x = (3, 4)$. المطلوب: $\nabla_x L$. الحل: الخطوة 1: $\partial L/\partial x_1 = 2x_1 = 6$؛ $\partial L/\partial x_2 = 2x_2 = 8$. النتيجة: $(6, 8)$، وطول التدرّج 10. الربط بالذكاء الاصطناعي: نزول التدرّج يقلّل المسافة للمبدأ.

مثال (11-2.36): softmax على ورقتين المعطيات: $L = \max(x_1, x_2)$ (عقدة max)، $x = (5, 3)$. المطلوب:

التدرّج (شبه منقطع). الحل: الخطوة 1: $\max = 5$ عند x_1. الخطوة 2: $\partial L/\partial x_1 = 1$ (الفرع النشط)؛ $\partial L/\partial x_2 = 0$. النتيجة: $(1, 0)$. الربط بالذكاء الاصطناعي: الmax-pooling يتبع نفس المنطق.

مثال (2.36-12): ضرب عنصري المعطيات: $L = u \odot v$، $u = (2, 3), v = (4, 5)$، نريد $\partial L/\partial u$. المطلوب: التدرّج. الحل: الخطوة 1: $L = (8, 15)$؛ $\partial L_i/\partial u_i = v_i$. النتيجة: $(4, 5) = v$. الربط بالذكاء الاصطناعي: الضرب العنصري شائع في الشبكات.

مثال (2.36-13): سين مقسوم المعطيات: $L = \sigma(w)/2$، $w = 0$. المطلوب: $\partial L/\partial w$. الحل: الخطوة 1: $\sigma(0) = 0.5$؛ $L = 0.25$. الخطوة 2: $\partial L/\partial \sigma = 0.5$؛ $\sigma'(0) = 0.25$. الخطوة 3: $0.5 \cdot 0.25 = 0.125$. النتيجة: 0.125. الربط بالذكاء الاصطناعي: سلسلةٌ عبر السّيجمويد.

مثال (2.36-14): رسم بثلاث طبقات المعطيات: $L = ((x \cdot 2) + 1)^2$، $x = 1$. المطلوب: dL/dx. الحل: الخطوة 1: $u = 2x = 2$؛ $v = u + 1 = 3$؛ $L = 9$. الخطوة 2: $\partial L/\partial v = 2v = 6$؛ $\partial v/\partial u = 1$؛ $\partial u/\partial x = 2$. الخطوة 3: $6 \cdot 1 \cdot 2 = 12$. النتيجة: 12. الربط بالذكاء الاصطناعي: تطابق الشبكة بعمق 3 وعرض 1.

مثال (2.36-15): تطبيق على الخسارة المعطيات: $L = (y_{\text{hat}} - y)^2$، $y_{\text{hat}} = 0.8, y = 1$. المطلوب: $\partial L/\partial y_{\text{hat}}$. الحل: الخطوة 1: الفرق -0.2؛ $L = 0.04$. الخطوة 2: $\partial L/\partial y_{\text{hat}} = 2(y_{\text{hat}} - y) = 2(-0.2) = -0.4$. النتيجة: -0.4. الربط بالذكاء الاصطناعي: نقطة انطلاق الانتشار العكسي الحقيقي.

أخطاء شائعة

- **نسيان اتجاه الرسم:** التمرير الأمامي من الجذور للنهاية، والعكسي بالعكس.
- **الخلط بين $\partial L/\partial v_i$ والمشتقّة المحليّة:** القاعدة (1.36) تجمع عبر كلِّ ابن.
- **إهمال DAG:** الرسوم الحلقية تكسر الترتيب الطوبولوجي.
- **معاملة max كقابلة للاشتقاق:** هي شبه منقطعة $\Rightarrow$ تدرّج الفرع النشط فقط.
- **حساب المشتقّة يدوياً لكلِّ معامل:** الانتشار العكسي يفعلها دفعةً.

صياغة رسمية: لطبقةٍ خطّيةٍ $z^{(\ell)} = W^{(\ell)} a^{(\ell-1)} + b^{(\ell)}$ بعقوبة خطأ واردة $\delta^{(\ell)} = \partial L/\partial z^{(\ell)}$، فإنَّ

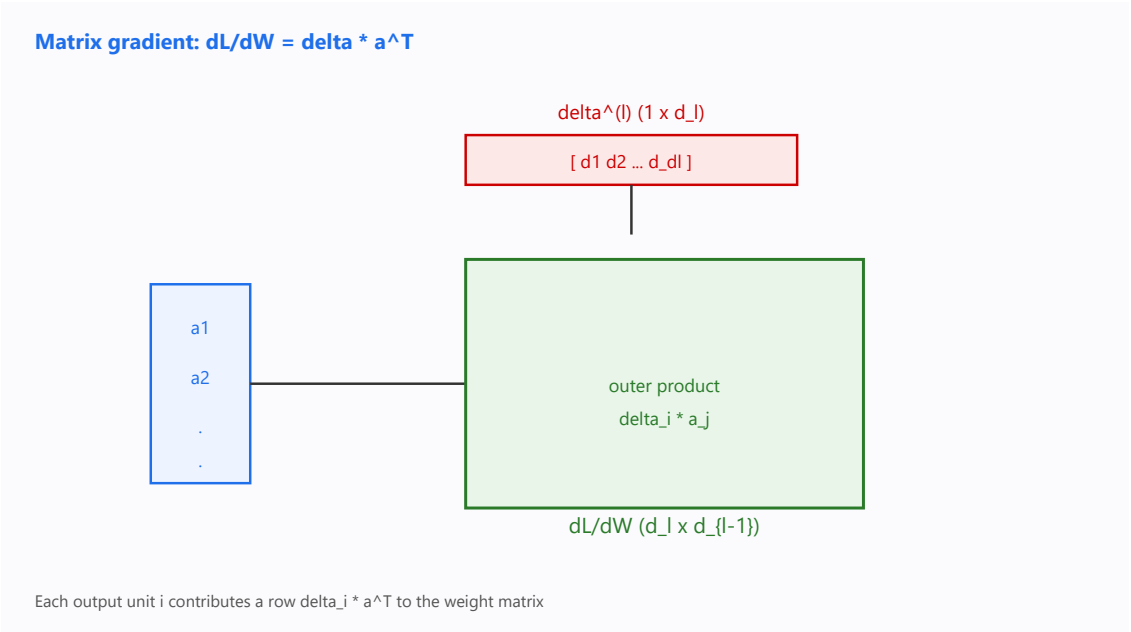
$$\frac{\partial L}{\partial W^{(\ell)}} = \delta^{(\ell)} \left(a^{(\ell-1)}\right)^{\top} \tag{2.36}$$

$$\frac{\partial L}{\partial a^{(\ell-1)}} = \left(W^{(\ell)}\right)^{\top} \delta^{(\ell)} \tag{3.36}$$

$$\frac{\partial L}{\partial b^{(\ell)}} = \delta^{(\ell)} \tag{4.36}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$\delta^{(\ell)}$	عقوبة الخطأ	$\partial L/\partial z^{(\ell)}$
$a^{(\ell-1)}$	نواتج الطبقة السابقة	متّجه عمود
$W^{(\ell)}$	مصفوفة الأوزان	$d_\ell \times d_{\ell-1}$
$\top$	transpose	منتج خارجي



شكل ٢.٣٦: *
تدرّج المصفوفة

الرسم

<figure> الشكل<figcaption> 2.36: $\partial L/\partial W$ يساوي منتجَ خارجيّاً $\delta(a^{(l-1)})^\top$؛ التدرّج حسب المعامل ي accumr من عقوبة الخطأ ومدخل الطبقة.</figcaption/> </figure>

البرهان

الخطوة 1 (بُعد المعادلة): $z^{(\ell)}$ أبعاد d_ℓ و$a^{(\ell-1)}$ أبعاد $d_{\ell-1}$؛ فـ$\delta(a^{(l-1)})^\top$ أبعاد $d_\ell \times d_{\ell-1}$ تطابق W. ■

الخطوة 2 (اشتقاق السلسلة): L تعتمد على W_{ij} عبر $z_i = \sum_j W_{ij}a_j$ فقط؛ $\partial z_i/\partial W_{ij} = a_j$، ومن ثمَّ $\partial L/\partial W_{ij} = \delta_i a_j$. ■

الخطوة 3 (التدرّج حسب المدخل): $a^{(\ell-1)} = \partial z/\partial a^{(\ell-1)}$ مضروباً في $\delta \Rightarrow (W^{(\ell)})^\top\delta$. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.36): حالة عددية صغيرة المعطيات: $a^{(0)} = [1,2]^\top$، $\delta^{(1)} = [0.3,0.7]^\top$، $W^{(1)}$ أبعاد 2×2. المطلوب: $\partial L/\partial W^{(1)}$. الحل: الخطوة 1: $\delta(a^{(0)})^\top = [0.3,0.7]^\top \cdot [1,2] = [0.3\cdot 1, 0.3\cdot 2; 0.7\cdot 1, 0.7\cdot 2]$. الخطوة 2: $= [[0.3,0.6],[0.7,1.4]]$. النتيجة: $[[0.3,0.6],[0.7,1.4]]$. الربط بالذكاء الاصطناعي: كلُّ عصبونٍ يساهم بصفٍّ في تدرّج الأوزان.

مثال (2-3.36): تدرّج التحيز المعطيات: $\delta^{(1)} = [0.3,0.7]^\top$. المطلوب: $\partial L/\partial b^{(1)}$. الحل: الخطوة 1: من (4.36) يساوي δ مباشرة. النتيجة: $[0.3,0.7]^\top$. الربط بالذكاء الاصطناعي: التحيزُ يُحدَّث بنفس عقوبة الخطأ.

مثال (3-3.36): تمرير للطبقة السابقة المعطيات: $W^{(2)} = \begin{bmatrix}1 & 0\\ 0 & 1\end{bmatrix}$، $\delta^{(2)} = [0.5,-0.2]^\top$. المطلوب: $\delta^{(1)}$. الحل: الخطوة 1: $(W^{(2)})^\top\delta^{(2)} = I\cdot[0.5,-0.2] = [0.5,-0.2]$. النتيجة: $[0.5,-0.2]^\top$. الربط بالذكاء الاصطناعي: الهويّة تُبقي عقوبة الخطأ دون تغيير.

مثال (36.3-4): مصفوفة غير مربّعة المعطيات: $W^{(1)}$ أبعاد 3×2، $a^{(0)} = [1,1]^\top$، $\delta^{(1)} = [1,2,3]^\top$. المطلوب: $\partial L/\partial W^{(1)}$. الحل: الخطوة 1: $[[1,1],[2,2],[3,3]] = [1,2,3]^\top \cdot [1,1] = \delta (a^{(0)})^\top$. النتيجة: مصفوفة 3×2 كلُّ صفّ مكرّر. الربط بالذكاء الاصطناعي: أبعاد المخرجات تحدّد عدد صفوف التدرّج.

مثال (36.3-5): وزن بعامل المعطيات: $W^{(1)} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$، $a^{(0)} = [1,3]^\top$، $\delta^{(1)} = [0.1, 0.4]^\top$. المطلوب: $\delta^{(0)}$ و$\partial L/\partial W^{(1)}$. الحل: الخطوة 1: $\partial L/\partial W = [[0.1, 0.3], [0.4, 1.2]]$. الخطوة 2: $\delta^{(0)} = 2I \cdot [0.1, 0.4] = [0.2, 0.8]$. النتيجة: $\delta^{(0)} = [0.2, 0.8]^\top$. الربط بالذكاء الاصطناعي: مضاعفة الأوزان تضاعف عقوبة الخطأ الصاعدة.

مثال (36.3-6): تحقّق الأبعاد المعطيات: $d_{\ell-1} = 4, d_\ell = 10$. المطلوب: أبعاد $\partial L/\partial W^{(\ell)}$. الحل: الخطوة 1: δ $(10) \times a$ $(4) \Rightarrow 4 \times 10$. النتيجة: تطابق أبعاد W. الربط بالذكاء الاصطناعي: فحص الأبعاد يكشف أخطاء البرمجة.

مثال (36.3-7): تراكم على الدُّفعة المعطيات: دُفعة $B = 3$ عيّنات، تدرّج كلٍّ منها كما في (36.3-1). المطلوب: التدرّج الكلّي. الحل: الخطوة 1: نجمع المصفوفات الثلاث. الخطوة 2: لو الثلاث متطابقة $\Rightarrow$ كلُّ مدخل $\times 3$. النتيجة: متوسّط/جمع على الدُّفعة. الربط بالذكاء الاصطناعي: تعلّم الدُّفعات يجمع تدرّجات العيّنات.

مثال (36.3-8): تدرّج حسب مدخل غير مربّع المعطيات: $W^{(2)}$ أبعاد 3×1، $\delta^{(2)} = [0.9]$، $a^{(1)} = [1,2,3]^\top$. المطلوب: $\partial L/\partial W^{(2)}$. الحل: الخطوة 1: $[0.9, 1.8, 2.7] = [1,2,3] \cdot 0.9$. النتيجة: صفّ واحد. الربط بالذكاء الاصطناعي: طبقة الإخراج ذات الخلية الواحدة.

مثال (36.3-9): التدرّج الصاعد لطبقتين المعطيات: $\delta^{(2)} = [0.5]$، $W^{(2)} = [2,1]$, $a^{(1)} = [1,2]^\top$ تمرّ عبر ReLU. المطلوب: $\delta^{(1)}$ قبل التنشيط. الحل: الخطوة 1: $\delta^{(1)} = (W^{(2)})^\top \delta^{(2)} = [2,1]^\top \cdot 0.5 = [1, 0.5]$. النتيجة: $[1, 0.5]^\top$ (قبل ضرب σ'). الربط بالذكاء الاصطناعي: سيُضرب لاحقاً بـσ' (4.36).

مثال (36.3-10): تحقّق عددي المعطيات: $L = \|Wa\|^2$، $W = [[1,0],[0,1]]$، $a = [3,4]^\top$. المطلوب: $\partial L/\partial W$ عند a. الحل: الخطوة 1: $z = a$، $L = 9 + 16 = 25$؛ $\delta = 2z = [6,8]$. الخطوة 2: $\partial L/\partial W = [[18,24],[24,32]] = [6,8]^\top \cdot [3,4]]$. النتيجة: $[[18,24],[24,32]]$. الربط بالذكاء الاصطناعي: التفاضل الآليّ يطابق التحليليّ.

مثال (36.3-11): استخدام التحيز في المُخمّن المعطيات: $\delta = [0.2, 0.2, 0.2]^\top$. المطلوب: تحديث التحيز بخطوة $\eta = 0.1$. الحل: الخطوة 1: $b \leftarrow b - 0.1 \cdot [0.2, 0.2, 0.2] = b - [0.02, 0.02, 0.02]$. النتيجة: كلُّ تحيز ينقص 0.02. الربط بالذكاء الاصطناعي: خطوة نزول التدرّج القياسيّ.

مثال (36.3-12): أبعاد غير متطابقة الطبقات المعطيات: $d_0 = 784, d_1 = 256$. المطلوب: أبعاد $\partial L/\partial W^{(1)}$. الحل: الخطوة 1: δ $(256) \times a$ $(784) \Rightarrow 256 \times 784$. النتيجة: 200,704 معاملاً في التدرّج. الربط بالذكاء الاصطناعي: يطابق عدد أوزان الطبقة الأولى.

مثال (36.3-13): وزن قطريّ بقيم مختلفة المعطيات: $W = \mathrm{diag}(0.5, 2)$، $\delta = [1,-1]^\top$. المطلوب: $\delta^{(0)}$. الحل: الخطوة 1: $\delta^{(0)} = (W)^\top \delta = [0.5, -2]^\top$. النتيجة: $[0.5, -2]^\top$. الربط بالذكاء الاصطناعي: اتجاهات مختلفة تُضخّم/تُخمّد التدرّج.

مثال (36.3-14): تحقّق التناظر المعطيات: $\partial L/\partial W_{ij}$ و $\partial L/\partial a_j$. المطلوب: العلاقة. الحل: الخطوة 1: $\partial L/\partial W_{ij} = \delta_i a_j$، و$\partial L/\partial a_j = \sum_i W_{ij}\delta_i$. النتيجة: الصيغتان (2.36)(3.36) متناظرتان عبر $W \leftrightarrow W^\top$. الربط بالذكاء الاصطناعي: هذا التناظر أساسُ كفاءة الانتشار.

مثال (36.3-15): تطبيق على خسارة MSE المعطيات: $L = \frac{1}{2}\|a^{(L)} - y\|^2$، $a^{(L)} = [0.8, 0.2]^\top$، $y = [1,0]^\top$. المطلوب: $\delta^{(L)}$. الحل: الخطوة 1: $\delta^{(L)} = a^{(L)} - y = [-0.2, 0.2]^\top$. النتيجة: $[-0.2, 0.2]^\top$. الربط بالذكاء الاصطناعي: نقطة البداية لكلِّ انتشار عكسيّ.

أخطاء شائعة

- **نسيان المنتج الخارجي:** $\partial L/\partial W$ ليس $\delta \odot a$ بل $\delta\, a^\top$.
- **خلط أبعاد** δ **و**a: δ صفّ (أو عمود حسب الاتفاق) وa عمود.
- **إهمال التحيز:** $\partial L/\partial b = \delta$ لا يُنسَ.
- **الظنّ أنّ** $\partial L/\partial a$ **يأتي من** W **لا** $W^\top$: الاتجاه معكوس.
- **جمع التدرّجات قبل تمرير الدُّفعة:** يؤدّي لأخطاء مقاس.

صياغة رسمية: لتنشيطٍ عنصريٍّ $a^{(\ell)} = \sigma(z^{(\ell)})$ حيث σ' مشتقّة عنصريّة، ناقل عقوبة الخطأ الصاعد هو

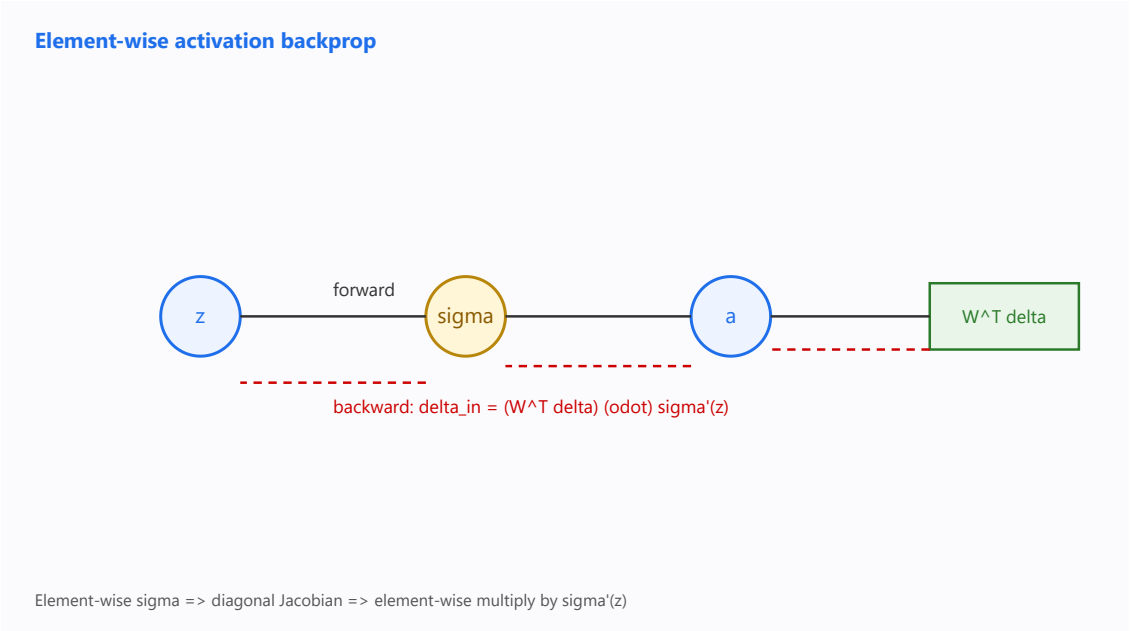
$$\delta^{(\ell-1)} = \left(W^{(\ell)}\right)^\top \delta^{(\ell)} \;\odot\; \sigma'\left(z^{(\ell-1)}\right) \tag{5.36}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$\odot$	ضرب عنصري	element-wise
σ'	مشتقّة التنشيط	قُطرية
$\delta^{(\ell)}$	عقوبة الطبقة ℓ	واردة

الرسم

<figure> الشكل<figcaption> 3.36: التدرّج الصاعد يمرّ عبر التنشيط بضرب عنصريّ في $\sigma'(z)$ ثمّ



شكل ٣٠٣٦: *
تنشيط عنصري

بـ$(W^{(\ell)})^\top$</figcaption>.</figure>

البرهان

الخطوة 1 (يعقوبية التنشيط): لأنَّ σ عنصريّة، $J_\sigma = \mathrm{diag}(\sigma'(z_i))$ قُطرية. ■

الخطوة 2 (السلسلة): $\delta^{(\ell-1)} = J_\sigma^\top (W^{(\ell)})^\top \delta^{(\ell)}$. بما أنَّ J_σ قُطرية متماثلة، فـ$J_\sigma^\top = J_\sigma \Rightarrow$ الضرب العنصري بـ$\sigma'(z)$. ■

خمسة عشر مثالاً محلولاً

مثال (4.36-1): ReLU المعطيات: $z = [2, -1, 0.5]^\top$، $\delta_{\text{in}} = [0.3, 0.4, 0.5]^\top$ (بعد $W^\top\delta$). المطلوب: δ_{out} قبل الطبقة. الحل: الخطوة 1: $\sigma'(z) = [1, 0, 1]$ (ReLU). الخطوة 2: $[0.3, 0.4, 0.5] \odot [1, 0, 1] = [0.3, 0, 0.5]$. النتيجة: $[0.3, 0, 0.5]^\top$ (العصبون السالب مات). الربط بالذكاء الاصطناعي: ReLU تُصفّر تدرّج العصبونات السالبة.

مثال (4.36-2): سِيجمويد المعطيات: $z = 1$، $\sigma(1) = 0.7311$، $\sigma'(1) = 0.7311(1 - 0.7311) = 0.1966$. المطلوب: عامل الضرب. الحل: الخطوة 1: $\sigma(1) = 0.7311$؛ الخطوة 2: $\sigma'(1) = 0.1966$. النتيجة: 0.1966. الربط بالذكاء الاصطناعي: التشبّع يضرب التدرّج.

مثال (4.36-3): tanh المعطيات: $z = 0.5$، $\tanh'(0.5) = 0.7864$. المطلوب: التأثير. الحل: الخطوة 1: $1 - \tanh^2(0.5) = 1 - 0.4621 = 0.5379$؟ (تحقّق: $\tanh 0.5 = 0.4621$، $1 - 0.2135 = 0.7865$) $\Rightarrow$ 0.7865. النتيجة: 0.7865. الربط بالذكاء الاصطناعي: tanh أقلّ إخماداً من السِّيجمويد.

مثال (4.36-4): ضرب في W^T المعطيات: $W^{(\ell)} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$، $\delta^{(\ell)} = [0.1, 0.2]^\top$، $\sigma'(z^{(l-1)}) = [1, 1]^\top$. المطلوب: $\delta^{(\ell-1)}$. الحل: الخطوة 1: $W^\top\delta = [[1, 3], [2, 4]] \cdot [0.1, 0.2] = [0.7, 1.0]^\top$. الخطوة 2: $[0.7, 1.0] \odot [1, 1] = [0.7, 1.0]^\top$. النتيجة: $[0.7, 1.0]^\top$. الربط بالذكاء الاصطناعي: دورةٌ كاملة للانتشار.

مثال (4.36-5): عصبون ميت المعطيات: $z = -5$ بـReLU. المطلوب: مساهمته. الحل: الخطوة 1: $\sigma'(-5) = 0$ $\Rightarrow$ δ الصاعد صفر. النتيجة: التدرّج لا يمرّ. الربط بالذكاء الاصطناعي: العصبونات الميتة لا تتعلّم.

مثال (4.36-6): LeakyReLU المعطيات: $z = -2$، $\mathrm{LReLU}' = 0.01$ بالسالب. المطلوب: التدرّج. الحل: الخطوة 1: الضرب بـ0.01 لا بالصفر. النتيجة: تسريبٌ طفيف يُبقي التدرّج. الربط بالذكاء الاصطناعي: leaky-ReLU يحلّ مشكلة الموت.

مثال (4.36-7): طبقة softmax (لا عنصريّة!) المعطيات: $\sigma = \mathrm{softmax}$. المطلوب: هل (5.36) تنطبق؟ الحل: الخطوة 1: يعقوبية softmax ليست قُطرية $\Rightarrow$ (5.36) لا تكفي. النتيجة: يلزم الصيغة الكاملة (انظر 6.36). الربط بالذكاء الاصطناعي: softmax تعاملٌ خاصّ.

مثال (4.36-8): ثلاث طبقات المعطيات: ReLU في كلٍّ، $z^{(1)} = [1, -1]$، $z^{(2)} = [0.5, 2]$، $W^{(3)} = [1, 1]$، $\delta^{(3)} = [0.2]$. المطلوب: $\delta^{(1)}$ التقريبيّ. الحل: الخطوة 1: $\delta^{(2)} = [1, 1]^\top \cdot 0.2 = [0.2, 0.2]$. الخطوة 2: بافتراض $W^{(2)} = I$، $\delta^{(1)} = [0.2, 0.2] \odot [1, 0] = [0.2, 0]$. النتيجة: $[0.2, 0]^\top$. الربط بالذكاء الاصطناعي: الانتشار عبر العمق.

مثال (4.36-9): تحقّق بقيمة المعطيات: $L = (a_1^{(1)})^2$، $a^{(1)} = \mathrm{ReLU}(z^{(0)})$، $z^{(0)} = 3$. المطلوب: $\delta^{(0)}$. الحل: الخطوة 1: $\delta^{(1)} = 2a^{(1)} = 6$؛ $\sigma'(3) = 1$. الخطوة 2: $\delta^{(0)} = 6 \cdot 1 = 6$. النتيجة: 6 (يطابق $d/dx(x^2) = 2x = 6$ عند $x = 3$). الربط بالذكاء الاصطناعي: التفاضل الآليّ يتطابق مع التحليليّ.

مثال (4.36-10): قناع التنشيط المعطيات: $z = [-1, 0, 1]$، ReLU. المطلوب: أيُّ عصبون يمرّر التدرّج؟ الحل: الخطوة 1: القناع $[0, 0, 1]$. النتيجة: العصبون الثالث فقط. الربط بالذكاء الاصطناعي: «بوّابات» ReLU تختار المسار.

مثال (4.36-11): تانح عند الصفر المعطيات: $z = 0$. المطلوب: $\tanh'(0)$. الحل: الخطوة 1: $1 - 0 = 1$. النتيجة: 1 (أقصى انتقال). الربط بالذكاء الاصطناعي: التانح قريبٌ من الخطّي حول الصفر.

مثال (12-4.36): تدرّج سالب المعطيات: $z = [1, 2]$، $\delta_{\text{in}} = [-0.5, 0.3]$، $\sigma' = [0.2, 0.1]$. المطلوب: الناتج. الحل: الخطوة 1: $[-0.5, 0.3] \odot [0.2, 0.1] = [-0.1, 0.03]$. النتيجة: $[-0.1, 0.03]$. الربط بالذكاء الاصطناعي: الإشارات تنتقل كما هي.

مثال (13-4.36): تنشيط GELU تقريبي المعطيات: $z = 1$، $\text{GELU}'(1) \approx 1.08$ (فعلياً $\text{GELU}'(1) \approx 0.84$). المطلوب: عامل. الحل: الخطوة 1: باستخدام القيمة 0.84. النتيجة: 0.84. الربط بالذكاء الاصطناعي: GELU أملس سلس.

مثال (14-4.36): طبقة بلا تنشيط المعطيات: $\sigma(x) = x$ (هويّة). المطلوب: ما σ'؟ الحل: الخطوة 1: $\sigma' = 1$. النتيجة: تُختزل لـ$(W^\top \delta)$ (5.36). الربط بالذكاء الاصطناعي: الطبقات الخطّية لا تصفّر.

مثال (15-4.36): تطبيق على انفجار المعطيات: σ' كبيرة (مثل 10) في سلسلة بعمق 3. المطلوب: الأثر. الحل: الخطوة 1: العامل $10^3 = 1000$ يضخّم δ. النتيجة: انفجار تدرّج محتمل. الربط بالذكاء الاصطناعي: يفسّر ضرورة التنظيم (7.36).

أخطاء شائعة

- **اعتبار softmax عنصرياً:** يعقوبيتها كاملة لا قُطرية.
- **نسيان $\odot$:** يجب ضرب عنصريّ لا مصفوفيّ.
- **الخلط بين σ' قبل/بعد:** التدرّج يستخدم $\sigma'(z^{(\ell-1)})$ الصاعد.
- **إهمال اتجاه $W^\top$:** هو $W^{(\ell)}$ المُحوّل لا $W^{(\ell)}$.
- **ظنّ ReLU قابلة للاشتقاق عند 0:** نعتمد المشتقّة اليمنى.

صياغة رسمية: لدالّة $f : \mathbb{R}^n \to \mathbb{R}$ مُمثَّلة رسماً حسابيّاً، يحسب **التفاضل العكسي** (reverse-mode AD) تدرّج ∇f بتكلفة

$$\text{cost}(\nabla f) \;\le\; C \cdot \text{cost}(f), \qquad C \in [2, 4] \text{ للعمليات الأوليّة} \tag{8.36}$$

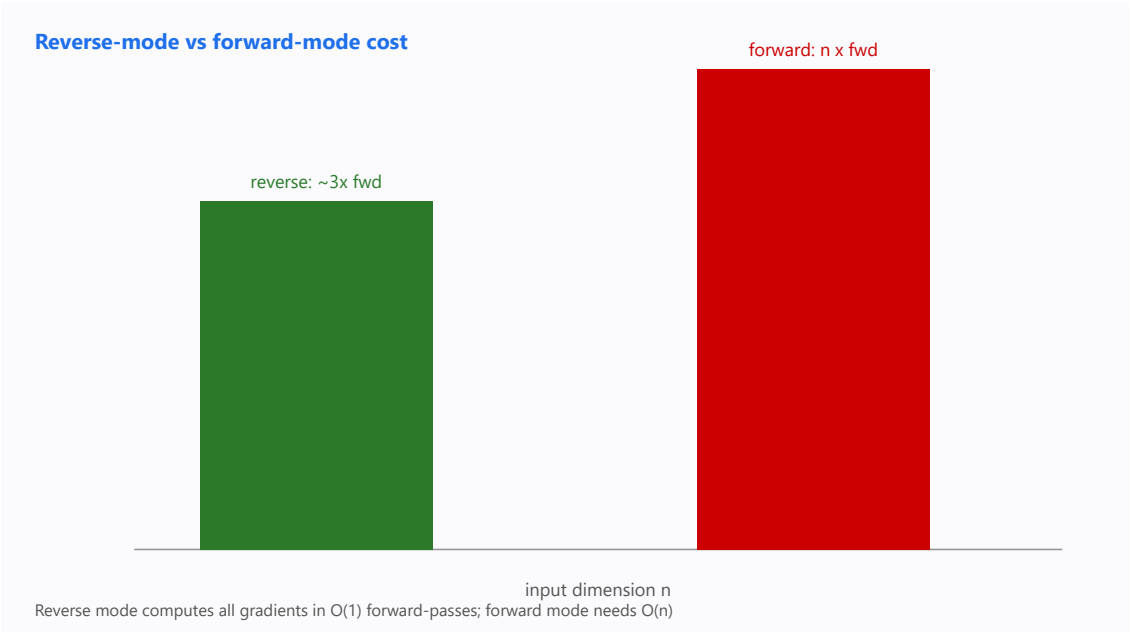
بينما **التفاضل الأماميّ** (forward-mode) بتكلفة $n \cdot \text{cost}(f)$. Hence reverse mode أفضلُ أُسّياً حين $n \gg 1$.

جدول الرموز

الرمز	المعنى	ملاحظة
$\text{cost}(f)$	تكلفة التمرير الأمامي	عمليات أساسية
C	مضاعيف ثابتة	≤ 4
n	بُعد المُدخل	عدد المعاملات

الرسم

<figure> الشكل<figcaption> 4.36: التفاضل العكسيّ بتكلفة $\approx (2\text{–}4)\times$ الأماميّ؛ الأماميّ بتكلفة $\approx n\times$؛ الفجوة تكبر مع n.</figcaption></figure>



شكل ٤٠٣٦: *
تعقيد التفاضل العكسي

البرهان (مخطّط)

الخطوة 1 (عدّ العمليات): كلُّ عقدة تُقيَّم مرةً واحدةً أماميّاً وتُحسب adjointها مرةً خلفياً $\Rightarrow$ على الأكثر ضعفا التكلفة + ثابت إضافي. ■

الخطوة 2 (الأماميّ): لحساب تدرّجٍ واحدٍ اتجاهيّ يمرّ مرةً واحدة لكنَّ للحصول على كامل ∇f يحتاج n تمريرة $\Rightarrow$ $n\times$. ■

الخطوة 3 (المقارنة): $C \ll n$ لـ n كبير $\Rightarrow$ العكسيّ متفوّق أُسّياً. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.36): عمليات صغيرة المعطيات: رسم بـ100 عملية، كلٌّ بتكلفة 1. المطلوب: تكلفة العكسيّ. الحل: الخطوة 1: أمامي 100، عكسي $\leq 400 = 4 \times 100$ كحدٍّ أعلى. النتيجة: ≤ 400 عملية. الربط بالذكاء الاصطناعي: التفاضل الآليّ في PyTorch.

مثال (2-5.36): مقارنة بـ1000 $= n$ المعطيات: نفس الرسم. المطلوب: تكلفة الأماميّ. الحل: الخطوة 1: $100{,}000 = 100 \cdot n$ عملية. النتيجة: العكسيّ أرخص بعامل 250. الربط بالذكاء الاصطناعي: سببُ هيمنة الانتشار العكسي.

مثال (3-5.36): نسبة فعلية المعطيات: قياسٌ أظهر عكسيّاً = $2.3\times$ الأماميّ. المطلوب: هل ضمن الحدّ؟ الحل: الخطوة 1: $2.3 \in [2, 4]$. النتيجة: نعم. الربط بالذكاء الاصطناعي: الحدّ النظري واقعيّ.

مثال (4-5.36): معاملات مليارية المعطيات: $n = 10^9$ (نموذج كبير). المطلوب: تكلفة الأماميّ. الحل: الخطوة 1: $10^9 \times \text{cost}(f)$ لا يُحتمل. النتيجة: العكسيّ وحده العمليّ. الربط بالذكاء الاصطناعي: تدريب LLMs يعتمد عليه.

مثال (5-5.36): عدد التمريرات المعطيات: تدرّج كامل vs تمريرة أمامية. المطلوب: كم تمريرة للأماميّ؟ الحل: الخطوة 1: n تمريرة للأماميّ مقابل 1 للعكسيّ. النتيجة: فجوة $n\times$. الربط بالذكاء الاصطناعي: العكسيّ «بمرّة واحدة لكلِّ

التدرّجات».

مثال (36.5-6): رسم خطّيّ المعطيات: $L = \theta^\top x$، $\dim\theta = 500$. المطلوب: تكلفة التدرّج. الحل: الخطوة 1: أمامي $O(500)$، عكسي نفس الرتبة. النتيجة: كلاهما $O(d)$. الربط بالذكاء الاصطناعي: للأبعاد الصغيرة الفرق بسيط.

مثال (36.5-7): فجوة عند $n = 10^6$ المعطيات: cost(f)=1000 op. المطلوب: التكلفة النسبية. الحل: الخطوة 1: عكسي ≈ 4000؛ أمامي $\approx 10^9$. النتيجة: العكسيّ أرخص بـ$250{,}000\times$. الربط بالذكاء الاصطناعي: لا بديل عمليّ عن العكسيّ.

مثال (36.5-8): تعقيد الذاكرة المعطيات: الرسم بحجم S عقدة. المطلوب: ذاكرة العكسيّ. الحل: الخطوة 1: يجب تخزين القيم الأمامية $\Rightarrow O(S)$. النتيجة: العكسيّ يستبدل حساباً بذاكرة. الربط بالذكاء الاصطناعي: «checkpointing» يقلّل الذاكرة.

مثال (36.5-9): اختبار الحدّ المعطيات: عملية باهظة (تفاف) في الرسم. المطلوب: هل يتضاعف الحساب؟ الحل: الخطوة 1: الأمام يحسبها؛ العكسي يعيد استخدامها + مشتقّة محليّة. النتيجة: $\approx$ضعف لا أكثر. الربط بالذكاء الاصطناعي: الالتفاف العكسي معروف التكلفة.

مثال (36.5-10): تدرّج جزئيّ المعطيات: نريد $\partial L/\partial\theta_k$ واحداً فقط. المطلوب: أيُّ وضع أفضل؟ الحل: الخطوة 1: الأماميّ أفضل هنا (تمريرة واحدة لاتجاه واحد). النتيجة: الأماميّ يتفوّق للتدرّج أحاديّ البُعد. الربط بالذكاء الاصطناعي: forward-mode يُستخدم في التفاضل الحسّاس.

مثال (36.5-11): بُعد مخرجات أكبر المعطيات: $f : \mathbb{R}^n \to \mathbb{R}^m$، نريد يعقوبية كاملة. المطلوب: ماذا يحدث؟ الحل: الخطوة 1: عكسيّ m تمريرة؛ أماميّ n تمريرة. النتيجة: اختر حسب m مقابل n. الربط بالذكاء الاصطناعي: Jacobian-vector products.

مثال (36.5-12): عدد العقد مقابل المعاملات المعطيات: $S = 10^4$ عقدة، $n = 10^7$ معامل. المطلوب: أيهما يحدّ التكلفة؟ الحل: الخطوة 1: التكلفة بأوبامات العقد والضرب، n تهيمن. النتيجة: المعاملات هي الحاكم. الربط بالذكاء الاصطناعي: مليارات المعاملات = مليارات العمليات.

مثال (36.5-13): التفاضل الرمزيّ المعطيات: مقارنة باشتقاق رمزيّ. المطلوب: التعليل. الحل: الخطوة 1: الرمزيّ ينفخ التعبير (expression swell)؛ الآليّ ثابت التكلفة. النتيجة: الآليّ أوفر. الربط بالذكاء الاصطناعي: سبب عدم استخدام sympy للشبكات.

مثال (36.5-14): التفاضل العدديّ المعطيات: فروق منتهية لكلِّ معامل. المطلوب: التكلفة. الحل: الخطوة 1: n تقييمات $f \Rightarrow O(n \cdot \text{cost}(f))$. النتيجة: مثل الأماميّ. الربط بالذكاء الاصطناعي: الفحص العددي بطيء (36.8).

مثال (36.5-15): ملخّص عمليّ المعطيات: شبكة $n = 10^8$. المطلوب: نظام التفاضل المُستخدم. الحل: الخطوة 1: العكسيّ بتكلفة ~(3–4)× الأماميّ. النتيجة: قابل للتدرّب عمليّاً. الربط بالذكاء الاصطناعي: هذا ما يجعل التعلّم العميق ممكنًا.

أخطاء شائعة

- **ظنّ التفاضل الآليّ = رمزيّ:** الآليّ يحسب قيماً لا تعبيرات.
- **ظنّه = فروق منتهية:** الآليّ دقّة الآلة لا $O(h)$.
- **نسيان أنَّ العكسيّ يخزّن القيم:** يحتاج ذاكرة $O(S)$.
- **الخلط بين forward/backward عند $m \ll n$:** الأماميّ أفضل أحياناً.

- **توقّع** $C = 1$: الحدّ الأدنى ~2 (أمامي + عكسي).

صياغة رسمية: لإخراج softmax $\hat{y}_i = e^{z_i} / \sum_j e^{z_j}$ مع خسارة إنتروبيا تقاطعية $L = -\sum_i y_i \ln \hat{y}_i$ (حيث y توزيع هدف)، فإنَّ

$$\frac{\partial L}{\partial z_i} = \hat{y}_i - y_i \tag{9.36}$$

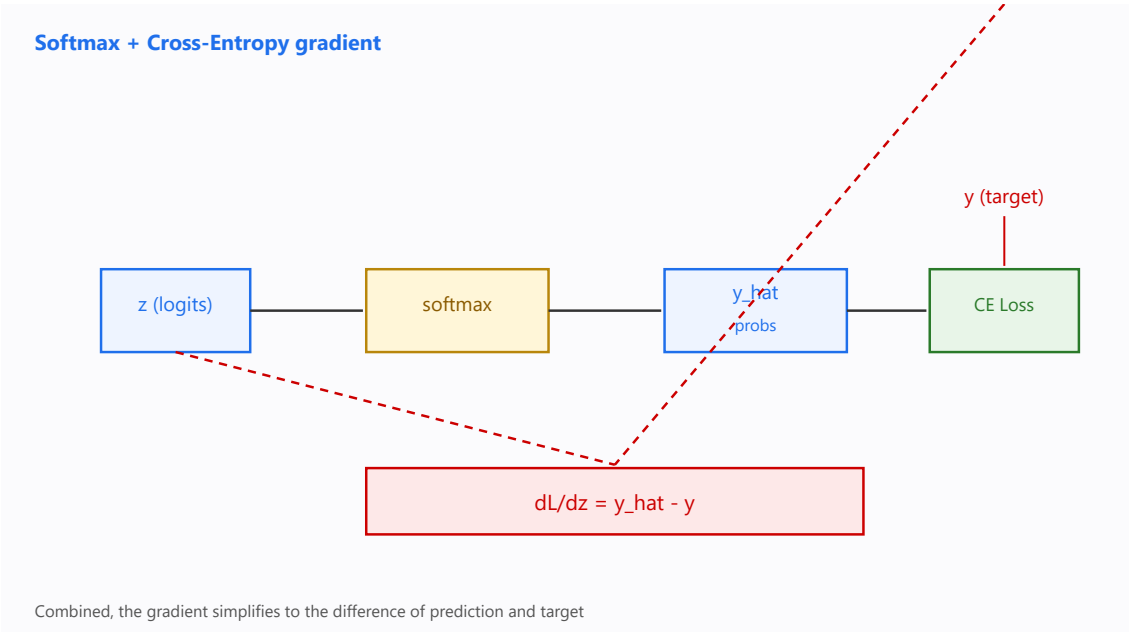
ولتطبيع الدُّفعة $z = \gamma \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta$، فإنَّ التدرّجُ الصاعد يحتاج مشتقّاتِ μ_B, σ_B^2 (صيغة منشَأة تعتمل المتوسطات).

جدول الرموز

الرمز	المعنى	ملاحظة
$\hat{y}$	احتمالات softmax	$\sum \hat{y}_i = 1$
y	الهدف (one-hot)	$\sum y_i = 1$
μ_B, σ_B^2	متوسط/تباين الدُّفعة	إحصاءات محلّية
γ, β	معاملات التطبيع	قابلة للتعلم

الرسم

<figure> الشكل<figcaption> 5.36: تركيب softmax ثمّ الإنتروبيا التقاطعية يُبسّط التدرّج إلى $y - \hat{y}$ بتطابقٍ



شكل ٥.٣٦: *
softmax والإنتروبيا

أنيق.<figcaption/> </figure>

البرهان

الخطوة 1 (مشتقّة softmax): $\partial \hat{y}_i / \partial z_k = \hat{y}_i(\delta_{ik} - \hat{y}_k)$. ■

الخطوة 2 (سلسلة مع L): $\partial L/\partial z_k = -\sum_i y_i (1/\hat{y}_i)\hat{y}_i(\delta_{ik} - \hat{y}_k) = -\sum_i y_i(\delta_{ik} - \hat{y}_k) = -y_k + \sum_i y_i \hat{y}_k = -y_k + \hat{y}_k$ (لأنَّ $\sum y_i = 1$). ■

الخطوة 3 (تطبيع الدُّفعة): بما أنَّ z يعتمد على μ_B, σ_B^2 اللذين يعتمدان على كلِّ x في الدُّفعة، فالتدرّج الصاعد مجموعٌ عبر الدُّفعة ويستخدم $\partial \mu_B/\partial x$، $\partial \sigma_B^2/\partial x$. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.36): تدرّج مباشر المعطيات: $\hat{y} = [0.7, 0.3]$، $y = [1, 0]$. المطلوب: $\partial L/\partial z$. الحل: الخطوة 1: $[0.7 - 1, 0.3 - 0] = [-0.3, 0.3]$. النتيجة: $[-0.3, 0.3]$. الربط بالذكاء الاصطناعي: التبسيط يسرّع التصنيف.

مثال (2-6.36): تنبؤ صحيح المعطيات: $\hat{y} = [0.95, 0.05]$، $y = [1, 0]$. المطلوب: التدرّج. الحل: الخطوة 1: $[0.95 - 1, 0.05 - 0] = [-0.05, 0.05]$. النتيجة: صغير $\Rightarrow$ تعلّم بطيء عند الثقة. الربط بالذكاء الاصطناعي: المقارب الصحيح يعطي تدرّجاً ضئيلاً.

مثال (3-6.36): ثلاث فئات المعطيات: $\hat{y} = [0.2, 0.3, 0.5]$، $y = [0, 0, 1]$. المطلوب: $\partial L/\partial z$. الحل: الخطوة 1: $[-0.2, -0.3, -0.5] = [-0.2, -0.3, 0.5 - 1]$. النتيجة: $[-0.2, -0.3, -0.5]$. الربط بالذكاء الاصطناعي: one-hot يترك باقي المكوّنات سالبة.

مثال (4-6.36): حساب softmax أولاً المعطيات: $z = [2, 1, 0.5]$ (لحساب $\hat{y}$). المطلوب: $\hat{y}$ ثمّ التدرّج مع $y = [1, 0, 0]$. الحل: الخطوة 1: $e^z = [7.389, 2.718, 1.649]$؛ المجموع 11.756. الخطوة 2: $\hat{y} = [0.628, 0.231, 0.140]$؛ التدرّج $[0.628 - 1, 0.231, 0.140] = [-0.372, 0.231, 0.140]$. النتيجة: $[-0.372, 0.231, 0.140]$. الربط بالذكاء الاصطناعي: يجب حساب softmax قبل التدرّج.

مثال (5-6.36): قيمة الخسارة المعطيات: $\hat{y} = [0.7, 0.3]$، $y = [1, 0]$. المطلوب: L. الحل: الخطوة 1: $-(1 \cdot \ln 0.7 + 0) = -\ln 0.7 = 0.3567$. النتيجة: $L = 0.3567$. الربط بالذكاء الاصطناعي: إنتروبيا تقاطعية تعاقب عدم الثقة.

مثال (6-6.36): استقرار عدديّ المعطيات: $z = [1000, 1000]$ (كبير). المطلوب: كيف نحسب بثبات؟ الحل: الخطوة 1: نطرح $\max z = 1000 \Rightarrow [0, 0]$. $\hat{y} = [0.5, 0.5]$. النتيجة: تفادي الفائض العدديّ. الربط بالذكاء الاصطناعي: log-sum-exp مستقرّ العمليّة.

مثال (7-6.36): تطبيع دُفعة بسيط المعطيات: دُفعة $[1, 3, 5]$، $\gamma = 1, \beta = 0$. المطلوب: z المُطبَّعة. الحل: الخطوة 1: $\mu = 3, \sigma^2 = (4 + 0 + 4)/3 = 2.667$؛ الخطوة 2: $\sqrt{2.667 + \epsilon} \approx 1.633$. $z = [-2/1.633, 0, 2/1.633] = [-1.225, 0, 1.225]$. النتيجة: $[-1.225, 0, 1.225]$. الربط بالذكاء الاصطناعي: التطبيع يثبّت التوزيع.

مثال (8-6.36): تدرّج γ في BN المعطيات: نفس الدُّفعة، $z = [-1.225, 0, 1.225]$. المطلوب: $\partial L/\partial \gamma$. الحل: الخطوة 1: $\partial L/\partial \gamma = \sum \delta_i \hat{x}_i = z_i/\gamma$ حيث $\hat{x}_i$ بلا β. الخطوة 2: بـ$\delta = [0.1, 0.2, 0.1] \Rightarrow$ $0.1(-1.225) + 0.2(0) + 0.1(1.225) = 0$. النتيجة: 0 (الدُّفعة متوازنة). الربط بالذكاء الاصطناعي: β, γ تُعلّمان كأيّ معامل.

مثال (9-6.36): β يُضبط للهدف المعطيات: نريد إزاحة z بـ$+0.5$. المطلوب: قيمة β المُستقرّة. الحل: الخطوة 1: $\beta = 0.5 \Rightarrow z_{\text{out}} = \gamma \hat{x} + \beta$. النتيجة: 0.5. الربط بالذكاء الاصطناعي: β تحرّك الوسط.

مثال (10-6.36): softmax عند التشبّع المعطيات: $z = [10, -10]$. المطلوب: $\hat{y}$. الحل: الخطوة 1: $e^{10} = 22026$، $e^{-10} = 4.54 \times 10^{-5}$؛ $\hat{y} \approx [1, 0]$. النتيجة: تشبّع كامل. الربط بالذكاء الاصطناعي: تدرّج عند التشبّع يُتابع صحيحاً.

مثال (11-6.36): تطابق الفرق المعطيات: (9.36) مع $\hat{y} = y$. المطلوب: التدرّج. الحل: الخطوة 1: $\hat{y} - y = 0$. النتيجة: 0 (تطابق تامّ). الربط بالذكاء الاصطناعي: لا تدرّج عند التطابق.

مثال (12-6.36): cross-entropy ثنائيّ المعطيات: $L = -y \ln p - (1-y)\ln(1-p)$، $p = \sigma(z)$. المطلوب: $\partial L/\partial z$. الحل: الخطوة 1: التدرّج $p - y$ (نفس النمط). النتيجة: $p - y$. الربط بالذكاء الاصطناعي: الحالة الثنائية تابعة لنفس النتيجة.

مثال (13-6.36): تدرّج الخسارة نفسها المعطيات: L مقابل $\hat{y}_1$. المطلوب: $\partial L/\partial \hat{y}_1$. الحل: الخطوة 1: $\partial L/\partial \hat{y}_1 = -y_1/\hat{y}_1$. النتيجة: قبل ضرب يعقوبية softmax. الربط بالذكاء الاصطناعي: الخطوة الأولى قبل (9.36).

مثال (14-6.36): BN أثناء الاختبار المعطيات: استخدام متوسطات التدريب لا الدُّفعة. المطلوب: الفرق في التدرّج. الحل: الخطوة 1: وقت الاختبار لا تدرّب $\Rightarrow \mu, \sigma$ ثابتة. (RunningStats) النتيجة: لا تدرّج لإحصاءات الدُّفعة. الربط بالذكاء الاصطناعي: وضع التقييم/eval يجمّد BN.

مثال (15-6.36): دمج softmax في الخسارة المعطيات: إطار عمل يدمج الاثنين. المطلوب: لماذا؟ الحل: الخطوة 1: التدرّج $\hat{y} - y$ يتجنّب القاسم غير المستقر. النتيجة: دقّة وأمان أعلى. الربط بالذكاء الاصطناعي: CrossEntropyLoss(softmax) مدمجة في PyTorch.

أخطاء شائعة

- **اشتقاق softmax يدوياً دون log-sum-exp:** قاسم غير مستقر عددياً.
- **نسيان أنَّ y مجموعها 1:** خطوة 9.36 تعتمد عليه.
- **تطبيق softmax ثمّ CE على قيم غير مُطبَّعة:** فيضان عدديّ.
- **ظنّ BN لا تدرّج لها:** μ, σ و γ, β كلها قابلة للتعلم.
- **خلط تدرّج softmax الصافي مع المُركَّب:** (9.36) هو الناتج بعد السلسلة.

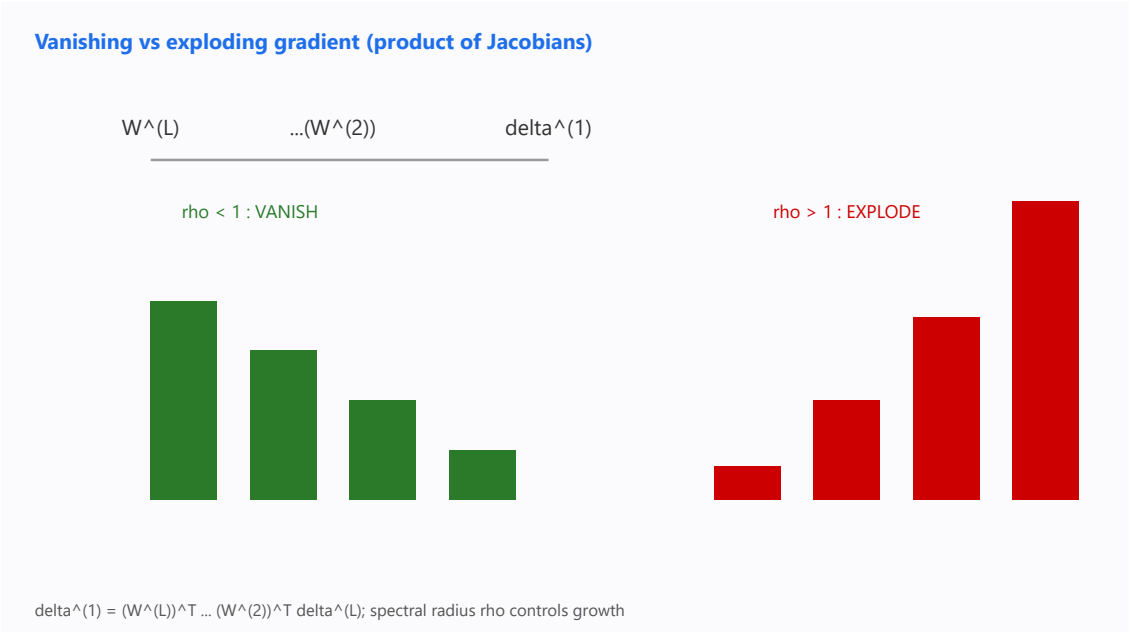
صياغة رسمية: عقوبة الخطأ في الطبقة الأولى تُعطى بجداء يعقوبيات الطبقات

$$\delta^{(1)} = \left(W^{(L)}\right)^{\top} \cdots \left(W^{(2)}\right)^{\top} \delta^{(L)} \tag{10.36}$$

فإذا كان أكبر قيمة ذاتية/نصف قطر طيفي $\rho = \max_{\ell} \rho(W^{(\ell)}) < 1$ فالتدرّج **يتلاشى** أُسّياً، وإن كان $\rho > 1$ **فينفجر.** تهيئة Xavier/He تحافظ على $\mathbb{E}[\|W^{(\ell)}\|^2] \approx 1$ عبر ضبط التباين $\frac{1}{d_{\text{in}}} = (\text{أو } 2/d_{\text{in}} \text{ ReLU})$.

جدول الرموز

الرمز	المعنى	ملاحظة
$\rho(W)$	نصف القطر الطيفي	أكبر قيمة مفردّة
$\|W\|$	معيار المعامل	طيفي/Frobenius
σ_W^2	تباين التهيئة	$1/d_{\text{in}}$
تلاشٍ/انفجار	اختفاء/تضخّم $\delta^{(1)}$	مع العمق



شكل ٦.٣٦: *
تلاشي وانفجار التدرّج

الرسم

<figure> الشكل<figcaption> 6.36: جداء اليعقوبيات $\prod W^{(\ell)}$؛ إن كانت القيم المفردة <1 تلاشى التدرّج، وإن كانت >1 انفجر.<figcaption/> </figure>

البرهان (مخطّط)

الخطوة 1 (حدّ النمو): $\|\delta^{(1)}\| \le \prod_\ell \|(W^{(\ell)})^\top\| \cdot \|\delta^{(L)}\| = \prod_\ell \sigma_{\max}(W^{(\ell)}) \cdot \|\delta^{(L)}\|$. ■

الخطوة 2 (تهيئة معتدلة): إن $\sigma_{\max}(W) \approx 1$ لكلّ ℓ فالجداء $\approx 1 \Rightarrow$ لا تلاشٍ ولا انفجار. ■

الخطوة 3 (Xavier/He): لطبقة $\mathbb{E}[z_i^2] = \sum_j W_{ij}^2 \mathbb{E}[a_j^2]$؛ باختيار $\mathrm{Var}(W_{ij}) = 1/d_{\text{in}}$ نحصل $\mathbb{E}[z_i^2] = \mathbb{E}[a_i^2] \Rightarrow$ تبقى الإشارة. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.36): جداء مُخَمِّد المعطيات: $W^{(\ell)} = 0.5\,I$ لـ $L = 5$ طبقات. المطلوب: عامل التلاشي. الحل: الخطوة 1: $\prod(0.5) = 0.5^5 = 0.03125$. النتيجة: التدرّج ينخفض لـ3% من قيمته. الربط بالذكاء الاصطناعي: طبقات عميقة تُخَمِّد التدرّج.

مثال (2-7.36): انفجار المعطيات: $W^{(\ell)} = 2\,I$، $L = 5$. المطلوب: عامل الانفجار. الحل: الخطوة 1: $2^5 = 32$. النتيجة: التدرّج يكبر 32×. الربط بالذكاء الاصطناعي: انفجار $\Rightarrow$ تدرّج NaN.

مثال (3-7.36): نصف قطر طيفي المعطيات: $W = \begin{bmatrix} 1.2 & 0 \\ 0 & 0.8 \end{bmatrix}$. المطلوب: ρ. الحل: الخطوة 1: القيم المفردة $\{1.2, 0.8\} \Rightarrow \rho = 1.2 > 1$. النتيجة: انفجار طفيف. الربط بالذكاء الاصطناعي: حتى ρ بسيط >1 يتراكم.

مثال (4-7.36): حالة معتدلة المعطيات: $W^{(\ell)}$ بقيم مفردة $\{1, 1\}$ (دوران). المطلوب: التدرّج. الحل: الخطوة 1: $\prod 1 = 1$. النتيجة: يبقى ثابتاً. الربط بالذكاء الاصطناعي: التحويلات التعامدية تحفظ التدرّج.

مثال (36.7-5): Xavier لطبقة المعطيات: $d_{\text{in}} = 100$. المطلوب: تباين التهيئة. الحل: الخطوة 1: $\sigma_W^2 = 1/100 = 0.01$. النتيجة: $W_{ij} \sim \mathcal{N}(0, 0.01)$. الربط بالذكاء الاصطناعي: Xavier لـtanh/sigmoid.

مثال (36.7-6): He لـReLU المعطيات: $d_{\text{in}} = 100$، ReLU. المطلوب: التباين. الحل: الخطوة 1: $\sigma_W^2 = 2/100 = 0.02$. النتيجة: $W_{ij} \sim \mathcal{N}(0, 0.02)$. الربط بالذكاء الاصطناعي: ReLU يفقد نصف الإشارة $\Rightarrow$ ضعف التباين.

مثال (36.7-7): عمق 50 بـHe المعطيات: $\rho \approx 1$ لكلِّ طبقة. المطلوب: التدرّج الكلّي. الحل: الخطوة 1: $\prod_{50} \approx 1$. النتيجة: تدرّج مستقر رغم العمق. الربط بالذكاء الاصطناعي: ResNet-50 يتعلّم بفضل التهيئة.

مثال (36.7-8): قياس التلاشي المعطيات: $\rho = 0.9$، $L = 20$. المطلوب: العامل النهائي. الحل: الخطوة 1: $0.9^{20} = 0.1216$. النتيجة: 12% فقط تصل للطبقة الأولى. الربط بالذكاء الاصطناعي: الطبقات المبكرة تتعلّم ببطء شديد.

مثال (36.7-9): مقارنة 99.0 مقابل 0.9 المعطيات: $L = 100$. المطلوب: العوامل. الحل: الخطوة 1: $0.99^{100} = 0.366$، $0.9^{100} = 2.66 \times 10^{-5}$. النتيجة: فارق هائل. الربط بالذكاء الاصطناعي: قرب الواحد حاسم.

مثال (36.7-10): تشخيص عمليّ المعطيات: خسارة لا تنخفض في الطبقات الأولى. المطلوب: الاحتمال. الحل: الخطوة 1: تلاشي التدرّج إذا $\rho < 1$ تراكمياً. النتيجة: استخدم تهيئة أفضل/وصلات متبقّية. الربط بالذكاء الاصطناعي: ResNet تحلّ التلاشي معمارياً.

مثال (36.7-11): نموّ القيمة المفردة المعطيات: $\sigma_{\max}$ يكبر خطأً في التعلّم. المطلوب: ماذا يحدث؟ الحل: الخطوة 1: $\prod \sigma_{\max}$ قد يتجاوز 1 $\Rightarrow$ انفجار. النتيجة: نحتاج تقليم/تطبيع التدرّج. الربط بالذكاء الاصطناعي: gradient clipping.

مثال (36.7-12): LSTM مقابل RNN المعطيات: بوّابات LSTM تمنع التلاشي. المطلوب: التعليل. الحل: الخطوة 1: مسار ثابت (ناقل الحالة) يحفظ التدرّج. النتيجة: أفضل لتسلسلات طويلة. الربط بالذكاء الاصطناعي: يُفسّر نجاح LSTM (Ch38).

مثال (36.7-13): تباين موحّد مقابل تباين طبقيّ المعطيات: $1/d_{\text{out}} = \sigma_W^2$ مقابل $1/d_{\text{in}}$. المطلوب: الفرق. الحل: الخطوة 1: Xavier يأخذ المتوسط؛ He للمدخل. النتيجة: تفاصيل طفيفة لا تُبطل المبدأ. الربط بالذكاء الاصطناعي: كليهما عمليّ.

مثال (36.7-14): قاسم مستقر المعطيات: $\rho = 1.01$، $L = 1000$. المطلوب: العامل. الحل: الخطوة 1: $1.01^{1000} \approx e^{10} \approx 22026$. النتيجة: انفجار هائل. الربط بالذكاء الاصطناعي: حتى 1% زيادة تتراكم.

مثال (36.7-15): حلّ التلاشي بـBatchNorm المعطيات: BN يضبط التباين لكلِّ طبقة. المطلوب: الأثر. الحل: الخطوة 1: BN يُبقي $\mathbb{E}[z^2]$ معتدلاً $\Rightarrow \rho \approx 1$. النتيجة: يخفّف التلاشي. الربط بالذكاء الاصطناعي: He + BN تركيبة قوية.

أخطاء شائعة

- **الخلط بين التلاشي (المخرجات) والانفجار:** كلاهما في التدرّج لا القيم.
- **نسيان أنَّ ρ تراكميٌّ:** 0.99^{100} صغير جداً.
- **تهيئة كلّ الطبقات بنفس التباين:** يجب $1/d_{\text{in}}$ متغيّر.
- **ظنّ ReLU لا تحتاج He:** توهجّ التباين يفسد التدريب.
- **الخلط بين $\sigma_{\max}$ والتباين:** الطيف يقيس الاستقرار، التباين يقيس التهيئة.

صياغة رسمية: نقرّب المشتقّة بالفروق المنتهية المتماثلة

$$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h} \tag{11.36}$$

وللتحقّق من صحّة الانتشار العكسي نقارن التدرّج التحليليّ g_{auto} بالعدديّ g_{num} عبر الخطأ النسبيّ

$$r = \frac{|g_{\text{num}} - g_{\text{auto}}|}{|g_{\text{num}}| + |g_{\text{auto}}| + 10^{-12}} \tag{12.36}$$

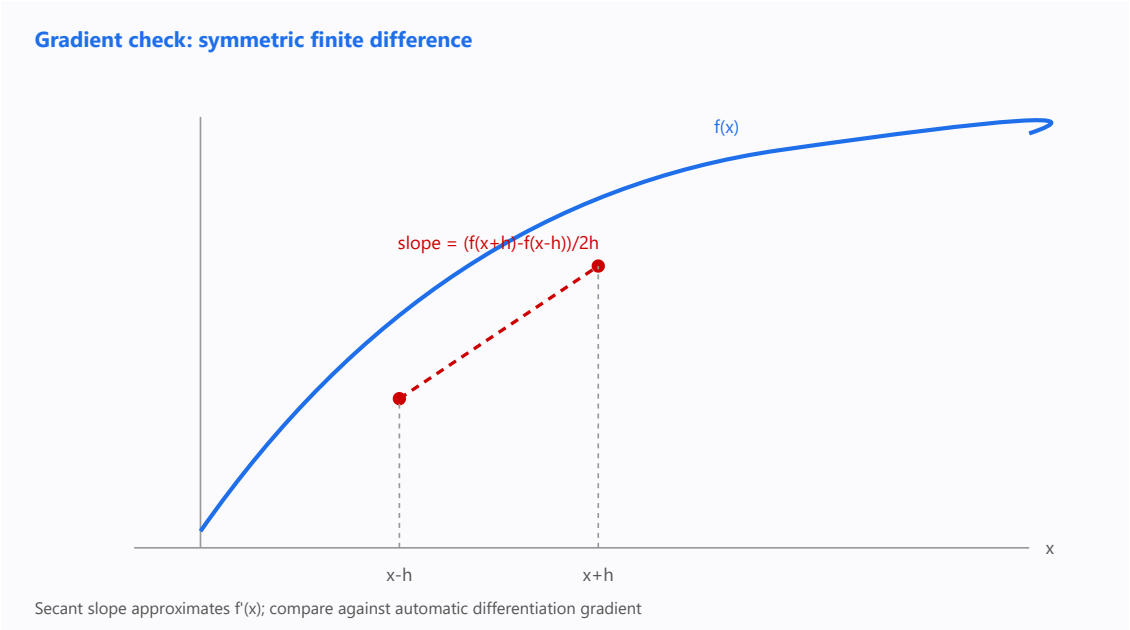
ونقبل إذا $r < 10^{-5}$ تقريباً (دقّة مزدوجة).

جدول الرموز

الرمز	المعنى	ملاحظة
h	خطوة الفروق	$\sim 10^{-5}$
g_{num}	تدرّج عدديّ	بطيء لكنّه موثوق
g_{auto}	تدرّج آليّ	سريع
r	خطأ نسبيّ	معيار القبول

الرسم

<figure> الشكل<figcaption> 7.36: ميل الوتر $(f(x+h) - f(x-h))/(2h)$ يقارب المشتقّة عند x؛ نستخدمه



شكل ٧.٣٦: *
فحص التدرّج

لفحص الانتشار العكسي.<figcaption/> </figure>

البرهان (مخطّط)

الخطوة 1 (خطأ التماثل): بتوسيع تايلور $f(x \pm h) = f(x) \pm hf'(x) + h^2 f''(x)/2 \pm h^3 f'''(x)/6 + \cdots$؛ طرحهما يلغي الزوجيّات $\Rightarrow$ الخطأ $O(h^2)$. ■

الخطوة 2 (اختيار h): صغر h يكبّر خطأ القطع العائم؛ القيمة المثلى $h \approx \sqrt{\epsilon_{\text{machine}}} \sim 10^{-8}$ (أو 10^{-5} عمليّاً). ■
الخطوة 3 (قبول الفحص): r صغير $\Rightarrow$ تنفيذ الانتشار العكسي صحيح. ■

خمسة عشر مثالاً محلولاً

مثال (36.8-1): تربيع المعطيات: $f(x) = x^2$، $x = 3$، $h = 0.01$. المطلوب: g_{num} و g_{auto}. الحل: الخطوة 1: $f(3.01) = 9.0601$، $f(2.99) = 8.9401$؛ $(9.0601 - 8.9401)/0.02 = 0.12/0.02 = 6.0$. الخطوة 2: $g_{\text{auto}} = 2x = 6.0$. النتيجة: $r \approx 0$. الربط بالذكاء الاصطناعي: الفحص الأساسيّ لأيِّ تنفيذ.

مثال (36.8-2): خطأ تايلور المعطيات: $h = 10^{-3}$ مقابل $h = 10^{-8}$ على نفس الدالّة. المطلوب: أيّ أدقّ؟ الحل: الخطوة 1: $h = 10^{-3}$ خطأ $O(10^{-6})$؛ $h = 10^{-8}$ قد يضخّم خطأ القطع. النتيجة: 10^{-3} أفضل هنا. الربط بالذكاء الاصطناعي: اختيار h موازنةٌ.

مثال (36.8-3): خطيّة المعطيات: $f(x) = 3x + 1$، $x = 2$. المطلوب: g_{num}. الحل: الخطوة 1: $(f(2.01) - f(1.99))/0.02 = (7.03 - 6.97)/0.02 = 3.0$. النتيجة: 3 (مطابق). الربط بالذكاء الاصطناعي: الدوالّ الخطّية يفحصها بسهولة.

مثال (36.8-4): سين المعطيات: $f(x) = \sin x$، $x = \pi/4$، $h = 10^{-5}$. المطلوب: g_{num} مقابل $\cos(\pi/4)$. الحل: الخطوة 1: $0.7071 \approx \cos(\pi/4)$. الخطوة 2: الفرق العددي ≈ 0.7071. النتيجة: تطابق. الربط بالذكاء الاصطناعي: فحص دوالّ المثلّثات.

مثال (36.8-5): خطأ نسبيّ مقبول المعطيات: $g_{\text{auto}} = 6.0$، $g_{\text{num}} = 6.0001$. المطلوب: r. الحل: الخطوة 1: $r = 0.0001/(12.0001) \approx 8.3 \times 10^{-6}$. النتيجة: $< 10^{-5} \Rightarrow$ مقبول. الربط بالذكاء الاصطناعي: عتبة القبول المعتادة.

مثال (36.8-6): فشل الفحص المعطيات: $g_{\text{auto}} = 5.5$، $g_{\text{num}} = 6$. المطلوب: r. الحل: الخطوة 1: $r = 0.5/11.5 = 0.0435$. النتيجة: كبير $\Rightarrow$ خطأ في التنفيذ. الربط بالذكاء الاصطناعي: فرق 4% يكشف بُغْمًا.

مثال (36.8-7): تكلفة الفحص المعطيات: $n = 10^6$ معامل. المطلوب: كم تقييم f؟ الحل: الخطوة 1: تقييمان لكلِّ معامل $\Rightarrow 2 \times 10^6$. النتيجة: بطيء جداً للتدريب. الربط بالذكاء الاصطناعي: الفحص للتصحيح لا للتدريب.

مثال (36.8-8): دالّة غير قابلة للاشتقاق المعطيات: $f(x) = |x|$ عند $x = 0$. المطلوب: ماذا يحدث؟ الحل: الخطوة 1: الفرق $(|h| - |-h|)/2h = 0$ لكنَّ المشتقّة غير معرّفة. النتيجة: الفحص يعطي 0 (متوسط). الربط بالذكاء الاصطناعي: نقاط الانكسار تخلط الفحص.

مثال (36.8-9): أبعاد متعدّدة المعطيات: $f(x, y) = x^2 + y^2$ عند $(1, 2)$. المطلوب: فحص $\partial f/\partial x$. الحل: الخطوة 1: $(f(1+h, 2) - f(1-h, 2))/2h = ((1+h)^2 + 4 - ((1-h)^2 + 4))/2h = (4h)/2h = 2$. النتيجة: $\partial f/\partial x = 2$ (يطابق $2x = 2$). الربط بالذكاء الاصطناعي: نفحص مكوّناً بمكوّن.

مثال (36.8-10): تطبيق على شبكة المعطيات: شبكة صغيرة، نفحص $\partial L/\partial W_{11}^{(1)}$. المطلوب: الخطوات. الحل: الخطوة 1: نضيف/نطرح h لـ $W_{11}^{(1)}$، نمرّر أماميّاً، نأخذ الفرق. النتيجة: تدرّج عدديّ لمعامل واحد. الربط بالذكاء الاصطناعي: check gradient في الكود.

مثال (36.8-11): خطأ القطع العائم المعطيات: $h = 10^{-12}$. المطلوب: الأثر. الحل: الخطوة 1: الفرق $f(x + h) - f(x - h)$ يفقد الدقّة بسبب الإلغاء. النتيجة: خطأ كبير رغم صغر h. الربط بالذكاء الاصطناعي: لا تختر h صغيراً جداً.

مثال (36.8-12): مقارنة معلومات الترتيب المعطيات: $g_{\text{num}} = 1e{-}6, g_{\text{auto}} = 0$. المطلوب: هل r كبير؟ الحل: الخطوة 1: $r = 1e-6/(1e-6) = 1$ (كلاهما صغير لكنَّ النسبة كارثية). النتيجة: تجنّب القاسم الصغير $\Rightarrow$ نستخدم 1e-12+. الربط بالذكاء الاصطناعي: الصيغة (12.36) تدافع عن ذلك.

مثال (36.8-13): ReLU عند نقطة نشطة المعطيات: $f = \text{ReLU}(x)$، $x = 2$. المطلوب: الفحص. الحل:

الخطوة 1: $(|2.01| - |1.99|)/0.02 = 0.02/0.02 = 1$. النتيجة: 1 (يطابق $\sigma' = 1$). الربط بالذكاء الاصطناعي: ReLU نشطة كالخطّي.

مثال (8.36-14): فحص دُفعة المعطيات: نفحص متوسّط خسارة الدُّفعة. المطلوب: هل يختلف؟ الحل: الخطوة 1: التدرّج = متوسّط تدرّجات العيّنات. النتيجة: الفحص يجب أن يطابق. الربط بالذكاء الاصطناعي: خطأ شائع متوسط/جمع.

مثال (8.36-15): تقرير الفحص المعطيات: $r_{\max} = 3 \times 10^{-7}$ عبر كلِّ المعاملات. المطلوب: الحكم. الحل: الخطوة 1: $< 10^{-5}$ لكلِّ المعاملات. النتيجة: التنفيذ صحيح. الربط بالذكاء الاصطناعي: اجتاز الفحص $\Rightarrow$ ننتقل للتدريب.

أخطاء شائعة

- **اختيار h صغيرٍ جداً:** يضخّم خطأ القطع العائم.
- **الاعتماد على الفروق الأمامية $(f(x+h) - f(x))/h$:** خطأ $O(h)$ أسوأ.
- **نسيان أنَّ الفحص بطيء:** لا يُستخدم أثناء التدريب.
- **الخلط بين الخطأ المطلق والنسبي:** (12.36) تستخدم النسبيّ.
- **فحص عند نقاط غير قابلة للاشتقاق:** يعطي قيماً مضلّلةً.

ملخّص النظريات

النظرية	المفهوم	الأهمّية
2.36 الرسم الحسابي	$\bar{v}_i = \sum \bar{v}_j \partial v_j / \partial v_i$	أساس التفاضل الآليّ
3.36 يعقوبية مصفوفية	$\partial L/\partial W = \delta a^\top$	تدرّج الأوزان
4.36 تنشيط عنصري	$\delta^{(l-1)} = (W^{(l)})^\top \delta^{(l)} \odot \sigma'$	الانتشار عبر الطبقات
5.36 تعقيد العكسي	الأمامي $\times (2-4) \le$	سبب هيمنة الانتشار العكسي
softmax+CE/BN 6.36	$\partial L/\partial z = \hat{y} - y$	تبسيط التدرّج
7.36 تلاشٍ/انفجار	$\rho = \sigma_{\max}(W)$	التهيئة Xavier/He
8.36 فحص التدرّج	$(f(x+h) - f(x-h))/2h$	التحقّق العدديّ

عشرون تمريناً (مع إجابات مختصرة)

١. قاعدة السلسلة على الرسم؟ (تجميع عبر الأبناء)

٢. $\partial L/\partial W^{(l)}$؟ $(\delta (a^{(l-1)})^\top)$

٣. $\partial L/\partial b^{(l)}$؟ $(\delta^{(l)})$

٤. تدرّج softmax+CE؟ $(\hat{y} - y)$

٥. لماذا العكسيّ أرخص من الأماميّ؟ ($O(1)$ مقابل $O(n)$ تمريرة)

٦. $\sigma'(2)$ للسِّيجمويد؟ (0.1050)

٧. ReLU عند $z = -3$؟ $(\sigma' = 0)$

٨. نصف قطر طيفي $\rho < 1$؟ (تلاشٍ)

٩. تباين Xavier لـ$d_{in} = 100$؟ (0.01)

١٠. تباين He لـReLU؟ $(2/d_{in})$

١١. عامل 0.9^{20}؟ (0.1216)

١٢. خطأ الفروق المتماثلة؟ $(O(h^2))$

١٣. لماذا لا نستخدم الفحص أثناء التدريب؟ (بطيء $2n$ تقييم)

١٤. لماذا softmax ليست عنصريّة؟ (يعقوبيتها كاملة)

١٥. ماذا يحدث بـ$\rho > 1$ لعمق كبير؟ (انفجار)

١٦. كيف يحلّ BN التلاشي؟ (يبقي $\rho \approx 1$)

١٧. $\partial L/\partial a^{(l-1)}$؟ $((W^{(l)})^\top \delta^{(l)})$

١٨. تكلفة العكسيّ كنسب من الأماميّ؟ $(2$–$4\times)$

١٩. قبول الفحص r؟ $(< 10^{-5})$

٢٠. لماذا التفاضل الآليّ لا رمزيّ؟ (لا انتفاخ تعبير)

فهرس الرموز

الرمز	المعنى
$\mathcal{G}$, v_i	الرسم الحسابي وعقده
$\bar{v}_i$	التدرّج العكسي (adjoint)
$\delta^{(\ell)}$	عقوبة الخطأ
J	اليعقوبية
$\rho(W)$	نصف القطر الطيفي
h	خطوة الفروق
r	الخطأ النسبيّ للفحص

مراجع

- Williams & Hinton Rumelhart, «Learning representations by back-propagating errors» (1986).
- Walther & Griewank — *Evaluating Derivatives: Principles and Techniques of Algorithmic Differentiation* (2008).
- Baydin et al., «Automatic Differentiation in Machine Learning: a Survey» (2018).
- Glorot & Bengio — «Understanding the difficulty of training deep feedforward networks» (Xavier, 2010).
- He et al., «Delving Deep into Rectifiers» (He initialization, 2015).
- Szegedy & Ioffe — «Batch Normalization» (2015).

- Courville & Bengio Goodfellow, — *Learning Deep*، الفصل 6 (التفاضل الآليّ).

خاتمة: أعطانا الانتشار العكسي آلةً لحساب أيّ تدرّجٍ بتكلفةٍ شبه ثابتةٍ؛ لكنَّ الشبكات الحقيقية لا تمرّر فقط — إنّها تلتفّ على الصور وتتذكّر الترتيب. التفافياً والذاكرة هما موضوعا **الفصلين 37 و38.**

الشبكات الالتفافية: الالتفاف، الطوبولوجيا، والتماثل

«الالتفافُ ليس خدعةً هندسيةً، بل تطبيقٌ لافتراضٍ قويٍّ: ما نبحث عنه في بكسلٍ نبحث عنه في كلِّ بكسل.»

بعد أن تعلّمنا في الفصل 36 حسابَ أيِّ تدرّجٍ، نتساءل: أيّ بنيةٍ تحوّل الصورَ إلى دلالات؟ الشبكات الالتفافية (CNN) تجيب بثلاثة مبادئ: **الاتصال المحلّي، مشاركة الأوزان، والتماثل الترجميّ.** هذا الفصل يُثبِتُ معادلاتِ حجم المخرجات، عدد المعاملات، التماثل، الحقول الاستقبالية، والانتشار العكسيّ للالتفاف، ويوضّحُ كفاءةَ المتغيّرات الحديثة. سبع نظريات:

- **2.37 الالتفام كمنتج داخليّ مُزاح (cross-correlation) وحجم المخرج** — صيغة $O = \lfloor (W - k + 2P)/S \rfloor + 1$.
- **3.37 الاتصال المحلّي ومشاركة الأوزان** — معامل# $= k^2 C_{in} C_{out} + C_{out}$.
- **4.37 التماثل والتبدّل الترجميّ** — $L(T_x f) = T_x L(f)$ vs (equivalence) $L(T_x f) = L(f)$ (invariance).
- **5.37 التجميع (Pooling)** — max/متوسّط والتبدّل.
- **6.37 الحقول الاستقبالية** — $RF_l = RF_{l-1} + (k_l - 1) \prod_{i<l} s_i$.
- **7.37 الانتشار العكسيّ عبر الالتفاف** — محوّل col2im/im2col.
- **8.37 كفاءة المتغيّرات (Separable/Grouped/Winograd)** — تقليل التكلفة.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
X	خريطة المُدخلات	$H \times W \times C_{in}$
K	نواة الالتفاف	$k \times k \times C_{in} \times C_{out}$
Y	خريطة المخرجات	$O \times O \times C_{out}$
k	حجم النواة	مربّعة عادةً
S	الخطوة (stride)	تَرحال النواة
P	الحشو (padding)	حواف صفرية
C_{in}, C_{out}	قنوات الدخل/الخرج	أعماق
RF	الحقل الاستقبالي	حجم النظر المحسوس
T_x	إزاحة (ترجمة)	operator shfit

الاتفاقيات: نعتمد اصطلاح **cross-correlation** الشائع في التعلّم العميق (لا قلب النواة) إلاّ حيث نذكر غير ذلك. كلّ المعادلات في كُتَل LTR.

صياغة رسمية: لخريطة دخل X ونواة K، عنصر المخرج

$$Y(i,j,c_{out}) = \sum_{c_{in}} \sum_{m,n} X(i+m, j+n, c_{in})\, K(m,n,c_{in},c_{out}) \tag{1.37}$$

وحجمُ المخرج المكانيّ لمُدخل طوله W هو

$$O = \left\lfloor \frac{W - k + 2P}{S} \right\rfloor + 1 \tag{2.37}$$

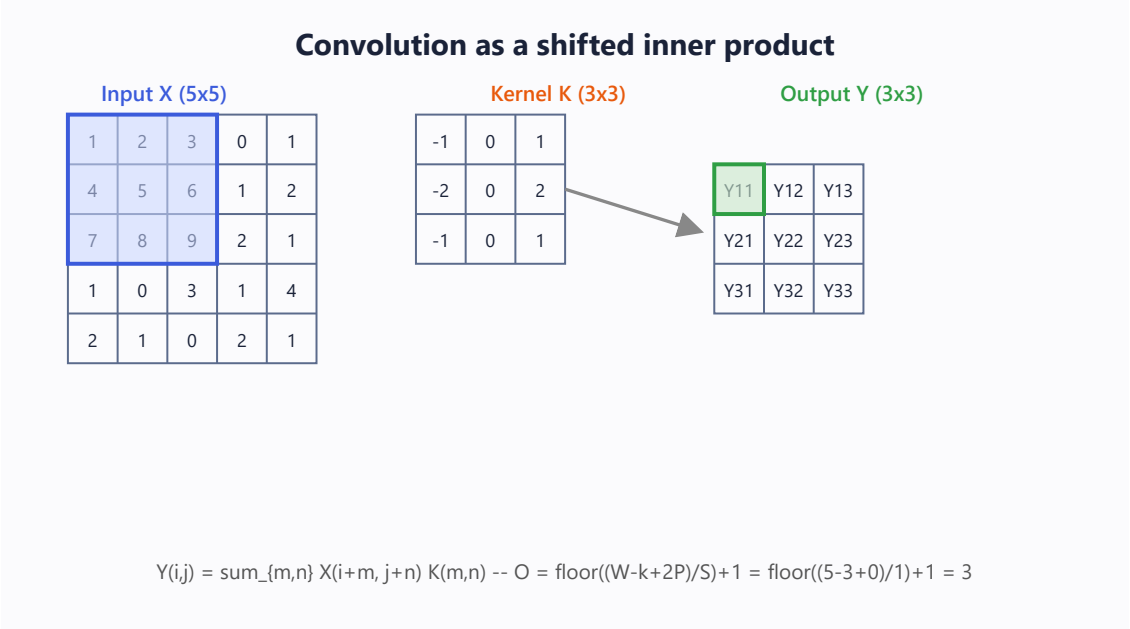
(متماثلٌ ارتفاعاً مع H).

جدول الرموز

الرمز	المعنى	ملاحظة
$Y(i,j,c)$	قيمة المخرج	عند الإحداثي
m, n	إزاحة داخل النواة	$0..k-1$
O	بُعد المخرج	مربّع مُفترض
$\lfloor \cdot \rfloor$	القاصي للأسفل	عدد المواضع الصالحة

الرسم

<figure> الشكل<figcaption> 1.37: نواة 3×3 تنزلق على الخريطة؛ في كلِّ موضعٍ نُجمعُ حاصلَ الضرب مع المُدخل



شكل ١٠٣٧: *
عملية الالتفاف

المُزاح.</figcaption> </figure>

البرهان

الخطوة 1 (عدّ المواضع): أقصى إحداثٍ بداية i يرضي $i+k-1 \le W-1+P$، أي $i \le W-k+2P+P$؟ بتعيين الحشو يصبح أقصى $i=(W-k+2P)$؛ عدد القيم من 0 إلى ذلك بخطوة S هو $\lfloor (W-k+2P)/S \rfloor$، فنضيف 1. ■

الخطوة 2 (صحّة (1.37)): هي تعريف الالتفاف المُفكَّك حسب القنوات والمواضع؛ مجموع الضربات هو المنتج الداخليّ المُزاح. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.37): حالة قاعدية المعطيات: $W=32, k=3, S=1, P=0$. المطلوب: O. الحل: الخطوة 1: $O = \lfloor (32-3+0)/1 \rfloor + 1 = 29+1 = 30$. النتيجة: 30. الربط بالذكاء الاصطناعي: التفاف بلا حشو يقلّص البُعد بـ$k-1$.

مثال (2-2.37): حشو يحافظ على الحجم المعطيات: $W=32, k=3, S=1, P=1$. المطلوب: O. الحل: الخطوة 1: $O = \lfloor (32-3+2)/1 \rfloor + 1 = 31+1 = 32$. النتيجة: 32 (بلا تغيّر مع $P=(k-1)/2$). الربط بالذكاء الاصطناعي: «same» padding.

مثال (3-2.37): خطوة 2 المعطيات: $W=224, k=7, S=2, P=3$. المطلوب: O. الحل: الخطوة 1: $O = \lfloor (224-7+6)/2 \rfloor + 1 = \lfloor 223/2 \rfloor + 1 = 111+1 = 112$. النتيجة: 112 (طبقة أولى شبيهة بـAlexNet). الربط بالذكاء الاصطناعي: اختزالٌ بمقدار النصف.

مثال (4-2.37): قاعدة الحفظ بـS=1 المعطيات: k فرديّة، $S=1$. المطلوب: P للحفظ. الحل: الخطوة 1: $W = \lfloor (W-k+2P)/1 \rfloor + 1 \Rightarrow W-k+2P+1 = W \Rightarrow P=(k-1)/2$. النتيجة: $P=1$ لـ$k=3$، $P=2$ لـ$k=5$. الربط بالذكاء الاصطناعي: قاعدة «same» القياسية.

مثال (5-2.37): تقليص متتالٍ المعطيات: 224، تلافيف $k=3, S=2, P=1$ مرّتين. المطلوب: الحجم بعد الاثنتين. الحل: الخطوة 1: الأولى $112 = \lfloor 223/2 \rfloor + 1 = \lfloor (224-3+2)/2 \rfloor + 1$. الخطوة 2: الثانية $= \lfloor (112-3+2)/2 \rfloor + 1 = \lfloor 111/2 \rfloor + 1 = 56$. النتيجة: $224 \to 112 \to 56$. الربط بالذكاء الاصطناعي: بنية تصغير تدريجيّ.

مثال (6-2.37): التفاف 1D المعطيات: طول $L=100, k=5, S=1, P=2$. المطلوب: O. الحل: الخطوة 1: $O = \lfloor (100-5+4)/1 \rfloor + 1 = 99+1 = 100$. النتيجة: 100 (حفظ بـ$P=(k-1)/2=2$). الربط بالذكاء الاصطناعي: تطبيق على الإشارات/النصوص.

مثال (7-2.37): التفاف مُفلطح (dilated) المعطيات: $k=3, d=2$ (اتساع)، $S=1, P=2$. المطلوب: حجم نواة فعّال. الحل: الخطوة 1: النواة الفعّالة $(k-1)d+1 = (2)\cdot 2+1 = 5$؛ $O = \lfloor (100-5+4)/1 \rfloor + 1 = 100$. النتيجة: مجال 5 بلا زيادة معامل. الربط بالذكاء الاصطناعي: اتساع (dilation) يوسّع الحقل الاستقبالي.

مثال (8-2.37): عدد عمليات الضرب-الجمع المعطيات: $O=30, C_{in}=3, C_{out}=64, k=3$. المطلوب: MACs. الحل: الخطوة 1: $30 \cdot 30 \cdot 3 \cdot 3 \cdot 64 = 1{,}555{,}200 \approx 1.56\text{M}$. النتيجة: ~56M عملية لكلِّ عيّنة. الربط بالذكاء الاصطناعي: حساب تكلفة الاستدلال.

مثال (9-2.37): نواة فردية القناة المعطيات: $C_{in}=1, C_{out}=1, k=3$، صورة 5×5، $K=[[1,0,-1],[2,0,-2],[1,0,-1]]$ (حافّة عمودية). المطلوب: $Y(1,1)$ بـ$P=0$. الحل: الخطوة 1: نأخذ النافذة $X[0..2,0..2]$ ونضرب في K ونجمع. الخطوة 2: (نفترض X مثلاً [[0,0,0],[10,10,0],[10,10,0]]) $\Rightarrow$ المجموع $\ldots + (0) + (0 + 0 \cdot 2 + 10 \cdot 1 + 10 \cdot 0) + (\ldots)$ نحسب: صف0: 10·0+10·1+0·0=10؛ صف1: (-1)·10+0·10+0·2+10·0=20؛ صف2: 0 $\Rightarrow$ المجموع 30). النتيجة: $Y(1,1)=30$ (كشف الحافّة). الربط بالذكاء الاصطناعي: نواة سوبل كلاسيكية.

مثال (10-2.37): خطوة 3 المعطيات: $W=28, k=3, S=3, P=0$. المطلوب: O. الحل: الخطوة 1:

$9 = 8 + 1 = \lfloor 25/3 \rfloor + 1 = \lfloor (28-3)/3 \rfloor + 1$. النتيجة: 9. الربط بالذكاء الاصطناعي: خطوات كبيرة تختزل سريعاً.

مثال (11-2.37): بُعدان مختلفان المعطيات: $H = 64, W = 128, k = 3, S = 1, P = 1$. المطلوب: المخرج. الحل: الخطوة 1: $H_{out} = 64$؛ $W_{out} = \lfloor (128 - 3 + 2)/1 \rfloor + 1 = 127$. النتيجة: 64×127. الربط بالذكاء الاصطناعي: غير مربّع مسموح.

مثال (12-2.37): لا ينقسم المعطيات: $W = 10, k = 3, S = 2, P = 0$. المطلوب: O. الحل: الخطوة 1: $\lfloor (10-3)/2 \rfloor + 1 = \lfloor 3.5 \rfloor + 1 = 3 + 1 = 4$. النتيجة: 4 (القاصي يهمل البكسل الزائدة). الربط بالذكاء الاصطناعي: حشو غير كافٍ يفقد حواف.

مثال (13-2.37): تفاف مُرتدّ (transposed) المعطيات: $O_{out} = \lfloor (W-1)S + k - 2P \rfloor + 1$. المطلوب: $W = 4, k = 3, S = 2, P = 0$. الحل: الخطوة 1: $(3) \cdot 2 + 3 - 0 + 1 = 6 + 3 + 1 = 10$? الصيغة $(4-1) \cdot 2 + 3 - 0 + 1 = 6 + 3 + 1 = 10$. النتيجة: 10 (تكبير/رفع عيّنات). الربط بالذكاء الاصطناعي: تفاف مرتدّ في المُشفّرات .(autoencoders)

مثال (14-2.37): عمق القنوات المعطيات: $C_{in} = 64, C_{out} = 128, k = 1$. المطلوب: O يبقى، ماذا يتغيّر؟ الحل: الخطوة 1: O حسب الفضاء، $C_{out} = 128$ قناة خرج. النتيجة: عمقٌ أكبر لا يغيّر الحجم المكانيّ. الربط بالذكاء الاصطناعي: تفاف 1×1 يغيّر العمق فقط.

مثال (15-2.37): التحقّق من الأبعاد المعطيات: هل O دائماً $\leq W$؟ المطلوب: متى؟ الحل: الخطوة 1: $S \geq 1, P$ معتدل، $O \leq W$ عادةً إلاّ بـ P كبير جداً. النتيجة: الحشو الزائد يكبّر المخرج. الربط بالذكاء الاصطناعي: تجنّب الحشو المفرط.

أخطاء شائعة

- **الخلط بين cross-correlation والالتفاف الرياضي:** DL يستعمل الأول (بلا قلب نواة).
- **نسيان القاصي للأسفل** في (2.37) $\Rightarrow$ حساب خاطئ للحجم.
- **افتراض** $P = (k-1)/2$ لـ k **الزوجي:** لا يحفظ الحجم تماماً.
- **إهمال تأثير** S**:** الخطوة الكبيرة تفقد تفاصيل.
- **خلط ارتفاع/عرض غير متماثلين:** (2.37) تُطبَّق كلٌّ على بُعده.

صياغة رسمية: لالتفاف بِنواة حجمها $k \times k$، C_{in} قناة دخل وC_{out} قناة خرج، يساوي عددُ المعاملات (الأوزان + الانحيازات)

$$N_{\text{param}} = k^2 \, C_{in} \, C_{out} + C_{out} \tag{3.37}$$

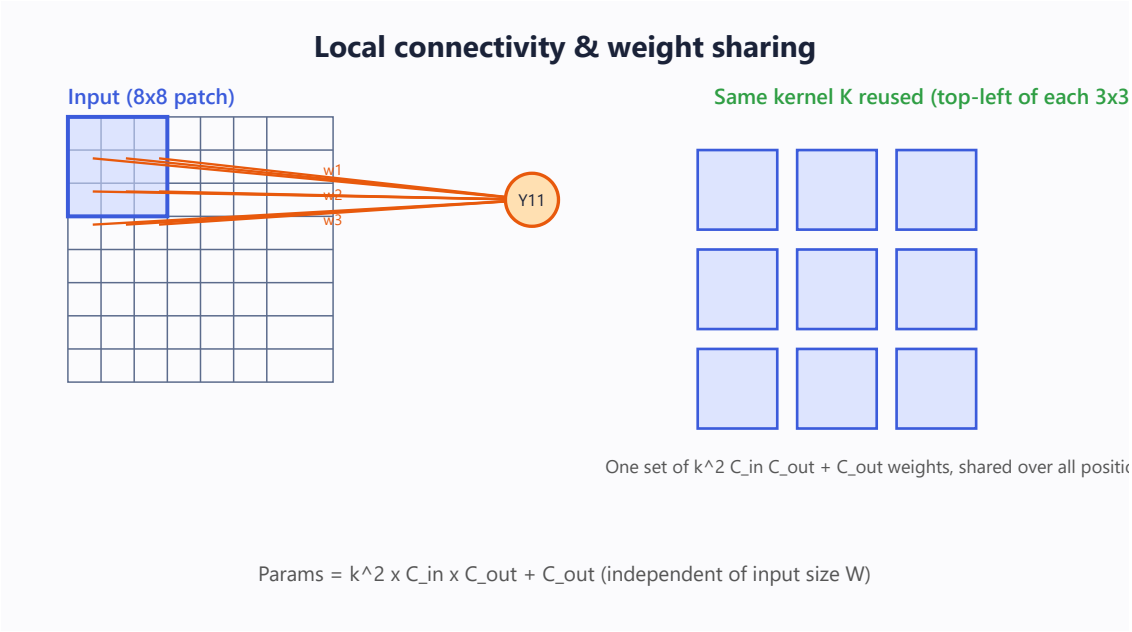
وهو **مستقل عن البُعد المكانيّ** W, H للمُدخل.

جدول الرموز

الرمز	المعنى	ملاحظة
k	حجم النواة	مربّعة
C_{in}, C_{out}	قنوات الدخل/الخرج	أعماق
$+C_{out}$	الانحيازات	وزن لكل قناة خرج

الرسم

<figure> الشكل<figcaption> 2.37: كل خلية خرج متصلة بنافذة $k \times k \times C_{in}$ محليّة؛ النواة نفسها تُشارَك على كل



شكل ٢.٣٧: *
الاتصال المحلي ومشاركة الأوزان

المواضع.<figcaption/> </figure>

البرهان

الخطوة 1 (النواة الواحدة): نواةٌ تربط قناة خرج واحدة بكلّ قنوات الدخل عبر نافذة $k \times k$ تحوي $k^2 C_{in}$ وزناً. ■

الخطوة 2 (تكرار القنوات): نُكرّر ذلك لـC_{out} قناة خرج $\Rightarrow k^2 C_{in} C_{out}$ وزن، زائداً انحيازاً لكل قناة $\Rightarrow +C_{out}$. ■

الخطوة 3 (استقلال البُعد): لا يدخل W أو H في (3.37)، فالالتفاف متناچ مكانيّاً. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.37): طبقة أولى من ResNet المعطيات: $k = 3, C_{in} = 3, C_{out} = 64$. المطلوب: N_{param}. الحل: الخطوة 1: $N = 3^2 \cdot 3 \cdot 64 + 64 = 9 \cdot 192 + 64 = 1728 + 64 = 1792$. النتيجة: 1792 معاملاً. الربط بالذكاء الاصطناعي: الطبقة الأولى رخيصة رغم الصورة 224×224.

مثال (2-3.37): التفاف عميق المعطيات: $k = 3, C_{in} = 64, C_{out} = 64$. المطلوب: N. الحل: الخطوة 1: $N = 9 \cdot 64 \cdot 64 + 64 = 9 \cdot 4096 + 64 = 36864 + 64 = 36928$. النتيجة: 36928. الربط بالذكاء الاصطناعي: كل ResNet المتكرّرة.

مثال (3-3.37): التفاف 1×1 المعطيات: $k = 1, C_{in} = 256, C_{out} = 512$. المطلوب: N. الحل: الخطوة 1: $N = 1 \cdot 256 \cdot 512 + 512 = 131072 + 512 = 131584$. النتيجة: 131584. الربط بالذكاء الاصطناعي: يغيّر العمق دون لمس المكان.

مثال (4-3.37): نواة كبيرة المعطيات: $k = 7, C_{in} = 3, C_{out} = 64$. المطلوب: N. الحل: الخطوة 1: $N = 49 \cdot 3 \cdot 64 + 64 = 49 \cdot 192 + 64 = 9408 + 64 = 9472$. النتيجة: 9472. الربط بالذكاء الاصطناعي: نواة

AlexNet الأولى.

مثال (3.37-5): نواة 5×5 المعطيات: $k = 5, C_{in} = 64, C_{out} = 128$. المطلوب: N. الحل: الخطوة 1: $N = 25 \cdot 64 \cdot 128 + 128 = 25 \cdot 8192 + 128 = 204800 + 128 = 204928$. النتيجة: 204928. الربط بالذكاء الاصطناعي: التفاف مكلف مكانيّاً.

مثال (3.37-6): قنوات متساوية كبيرة المعطيات: $k = 3, C_{in} = 256, C_{out} = 256$. المطلوب: N. الحل: الخطوة 1: $N = 9 \cdot 256 \cdot 256 + 256 = 9 \cdot 65536 + 256 = 589824 + 256 = 590080$. النتيجة: 590080. الربط بالذكاء الاصطناعي: أثقل طبقات ResNet-50 المتوسّطة.

مثال (3.37-7): مقارنة 3×3 مقابل 5×5 المعطيات: $C_{in} = C_{out} = 128$. المطلوب: النسبة. الحل: الخطوة 1: $N_3 = 9{\cdot}128^2{+}128 = 9{\cdot}16384{+}128 = 147456{+}128 = 147584$. الخطوة 2: $N_5 = 25{\cdot}16384{+}128 = 409600 + 128 = 409728$. الخطوة 3: النسبة $N_5/N_3 \approx 2.78$. النتيجة: 5×5 أثقل بنحو 8.2 ضعفاً. الربط بالذكاء الاصطناعي: لذلك تُفضّل سلسلة 3×3.

مثال (3.37-8): الانحيازات وحدها المعطيات: $C_{out} = 1024$. المطلوب: حصّة الانحيازات من (3.37-6). الحل: الخطوة 1: $1024/590080 \approx 0.0017 = 0.17\%$. النتيجة: الانحيازات مهملة الحجم. الربط بالذكاء الاصطناعي: تُجمّع عادةً مع الأوزان في tensor واحد.

مثال (3.37-9): صورة كبرى لا تؤثّر المعطيات: $W = 224$ مقابل $W = 1024$، نفس k, C. المطلوب: هل تتغيّر N؟ الحل: الخطوة 1: (3.37) لا تحوي $W \Rightarrow$ ثابتة. النتيجة: N متطابقة. الربط بالذكاء الاصطناعي: سبب قابلية CNN للتعميم على دقّات مختلفة.

مثال (3.37-10): التفاف 1×1 بعمق كبير المعطيات: $k = 1, C_{in} = 512, C_{out} = 2048$. المطلوب: N. الحل: الخطوة 1: $N = 1 \cdot 512 \cdot 2048 + 2048 = 1048576 + 2048 = 1050624$. النتيجة: 1050624. الربط بالذكاء الاصطناعي: توسيع البعد في MobileNet.

مثال (3.37-11): نواة 3×3 بقناتين دخل المعطيات: $k = 3, C_{in} = 2, C_{out} = 16$. المطلوب: N. الحل: الخطوة 1: $N = 9 \cdot 2 \cdot 16 + 16 = 288 + 16 = 304$. النتيجة: 304. الربط بالذكاء الاصطناعي: طبقة تجريبيّة صغيرة.

مثال (3.37-12): التحقّق من الأبعاد المعطيات: $N = 590080$ من (3.37-6). المطلوب: استرجاع C. الحل: الخطوة 1: $9C^2 + C - 590080 = 0 \Rightarrow C \approx 256$. النتيجة: $C = 256$. الربط بالذكاء الاصطناعي: التحقّق من بنية النموذج.

مثال (3.37-13): مقارنة بطبقة كاملة المعطيات: دخل $224^2 \cdot 3 = 150528$، خرج $C_{out} = 64$. المطلوب: عدد معاملات طبقة كاملة مقابل التفاف 3×3. الحل: الخطوة 1: كاملة $150528 \cdot 64 + 64 \approx 9.63 \times 10^6$. الخطوة 2: التفاف $= 1792$. الخطوة 3: النسبة ≈ 5378 ضعفاً. النتيجة: الالتفاف أوفر بستّة رتب. الربط بالذكاء الاصطناعي: جوهر كفاءة CNN.

مثال (3.37-14): عمق مضاعف المعطيات: $k = 3, C_{in} = 64, C_{out} = 128$. المطلوب: N. الحل: الخطوة 1: $N = 9 \cdot 64 \cdot 128 + 128 = 9 \cdot 8192 + 128 = 73728 + 128 = 73856$. النتيجة: 73856. الربط بالذكاء الاصطناعي: كلّ مضاعفة عمق تضاعف الأوزان.

مثال (3.37-15): النواة المربّعة الافتراض المعطيات: لو k غير مربّعة $k_h \times k_w$. المطلوب: التعميم. الحل: الخطوة 1: $N = k_h k_w C_{in} C_{out} + C_{out}$. النتيجة: الصيغة تحلّ محل k^2. الربط بالذكاء الاصطناعي: نوى مستطيلة في بعض المعماريّات.

أخطاء شائعة

- **ظنّ أن عدد المعاملات يعتمد على W:** الاستقلال المكانيّ جوهريّ.
- **نسيان الانحيازات في (3.37) $\Rightarrow$ نقص C_{out}.**
- **خلط 1×1 بالطبقة الكاملة:** 1×1 التفاف لا يخلط المواضع.

- **إهمال مشاركة الوزن:** جعلها طبقة كاملة يفجّر المعاملات.
- **افتراض $C_{in} = C_{out}$ دائماً:** غالباً يختلفان.

صياغة رسمية: لتحويل الترجمة T_x (إزاحة بـx) وعملية التفاف L بنواة ثابتة،

$$L(T_x f) = T_x L(f) \tag{4.37}$$

أي **تبدّل ترجميّ.** أما التجميع الأقصى (أو المتوسّط) بخطوة مساوية لحجم النافذة فهو **ثابت ترجمياً**:

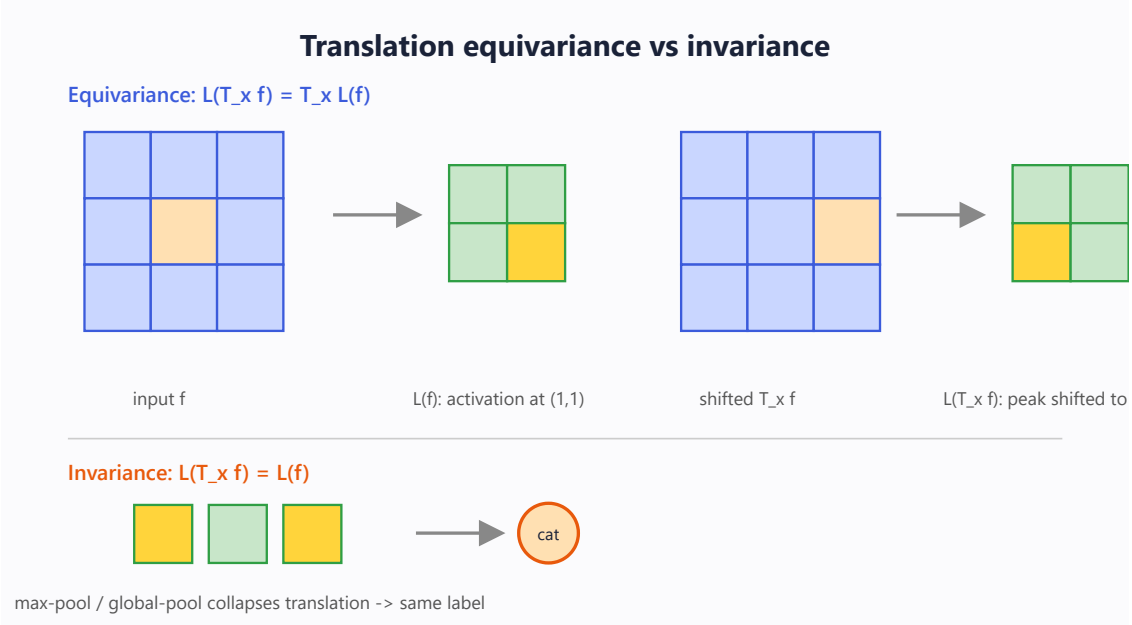
$$P(T_x f) = P(f) \quad \text{عند الإزاحة بضmultiple من الخطوة.} \tag{5.37}$$

جدول الرموز

الرمز	المعنى
T_x	إزاحة (ترجمة) بـx
L	طبقة التفاف
P	طبقة تجميع

الرسم

<figure> الشكل<figcaption> 3.37: الالتفاف يُزاح مع الدخل (تبدّل)؛ التجميع يطوي الترجمة (ثبات).</figcaption>



شكل ٣٠٣٧: *
التماثل الترجمي

</figure>

البرهان

الخطوة 1 (تبدّل الالتفاف): $(L(T_x f))(i) = \sum_m T_x f(i+m)K(m) = \sum_m f(i+m-x)K(m) = L(f)(i-x) = (T_x L(f))(i)$. ■

الخطوة 2 (ثبات التجميع): إن كان التجميع على نوافذ لا تتداخل والإزاحة مضاعفاً لخطوتها، تنتقل كلّ قيمة لنفس خانة التجميع $\Rightarrow$ الناتج ثابت. ■

خمسة عشر مثالاً محلولاً

مثال (37.4-1): تبدّل دائري 1D المعطيات: $f = [1,2,3,4]$، $K = [1,0,-1]$ (دائريّة)، إزاحة يمين 1. المطلوب: تحقّق (37.4). الحل: الخطوة 1: $L(f) = [f_0 - f_2, f_1 - f_3, f_2 - f_0, f_3 - f_1] = [-2,-2,2,2]$. الخطوة 2: $T_1 f = [4,1,2,3]$؛ $L(T_1 f) = [4-2, 1-3, 2-4, 3-1] = [2,-2,-2,2]$. الخطوة 3: $T_1 L(f) = [L_3, L_0, L_1, L_2] = [2,-2,-2,2]$. متطابق. النتيجة: $L(T_1 f) = T_1 L(f)$. الربط بالذكاء الاصطناعي: كشف الملمح في أيّ موقع.

مثال (37.4-2): إزاحة يسار المعطيات: نفس f, K، إزاحة يسار 1 (T_{-1}). المطلوب: تحقّق. الحل: الخطوة 1: $T_{-1} f = [2,3,4,1]$؛ $L = [2-4, 3-1, 4-2, 1-3] = [-2,2,2,-2]$. الخطوة 2: $T_{-1} L(f) = [L_1, L_2, L_3, L_0] = [-2,2,2,-2]$. متطابق. النتيجة: التبدّل يحمل الاتجاه. الربط بالذكاء الاصطناعي: الاتجاه لا يضيع.

مثال (37.4-3): ثبات التجميع الأقصى المعطيات: $X = [[1,3],[4,7]]$، إزاحة يمين بخطوة 2. المطلوب: هل P ثابت؟ الحل: الخطوة 1: max $P(X) = 7$ النافذة =. الخطوة 2: إزاحة بضmultiple من الخطوة 2 تبقي القيم ضمن نفس النافذة $\Rightarrow$ الناتج 7. النتيجة: ثابت. الربط بالذكاء الاصطناعي: تصنيف لا يتأثّر بموضع الطُّعم.

مثال (37.4-4): إزاحة دون مضاعف الخطوة المعطيات: $X = [1,5,2,8]$، max-pool نافذة 2 بخطوة 2. المطلوب: إزاحة 1. الحل: الخطوة 1: $P(X) = [\max(1,5), \max(2,8)] = [5,8]$. الخطوة 2: $T_1 X = [0,1,5,2]$، $P = [\max(0,1), \max(5,2)] = [1,5] \neq [5,8]$. النتيجة: ليس ثابتاً لإزاحة جزئية. الربط بالذكاء الاصطناعي: الترجمة الدقيقة تكسر الثبات.

مثال (37.4-5): تبدّل في 2D المعطيات: نواة حافة عمودية $K = [[1,0,-1],[1,0,-1],[1,0,-1]]$. المطلوب: إزاحة الدخل يميناً تُزاح الخريطة. الحل: الخطوة 1: بفرض تلبية الحدود، $L(T_x f) = T_x L(f)$ من (37.4). النتيجة: الحواف تظهر مزاحة الموقع. الربط بالذكاء الاصطناعي: كشف الحواف موضعيّ.

مثال (37.4-6): مقارنة عدد المعاملات للتبدّل المعطيات: شبكة التفاف مقابل طبقة كاملة على صورة $32 \times 32 \times 3$. المطلوب: بيّن أثر التبدّل. الحل: الخطوة 1: التفاف $k = 3, C_{out} = 16 \Rightarrow 9 \cdot 3 \cdot 16 + 16 = 448$ معاملاً. الخطوة 2: كاملة $32 \cdot 32 \cdot 3 \cdot 16 + 16 = 49168 \approx 3072 \cdot 16$. النتيجة: التبدّل يوفّر المعاملات. الربط بالذكاء الاصطناعي: السبب الرياضيّ للقابلية للتعميم.

مثال (37.4-7): ثبات عبر pool average global المعطيات: خريطة $7 \times 7 \times 512$. المطلوب: هل GAP ثابت ترجمياً؟ الحل: الخطوة 1: GAP يجمع كلّ الخريطة $\Rightarrow$ أيّ إزاحة ضمنها لا تغيّر المتوسّط الكلّيّ. النتيجة: نعم ثابت. الربط بالذكاء الاصطناعي: GAP في Network-in-Network.

مثال (37.4-8): إثبات التبدّل بالتعريف (تفصيل) المعطيات: $f(i) = i$ لـ $i = 0..3$ دائرياً، $K = [1,-1]$. المطلوب: $L(T_1 f)$ و$T_1 L(f)$. الحل: الخطوة 1: $L(f) = [f_0 - f_1, f_1 - f_2, f_2 - f_3, f_3 - f_0] = [-1,-1,-1,3]$. الخطوة 2: $T_1 f = [3,0,1,2]$؛ $L = [3-0, 0-1, 1-2, 2-3] = [3,-1,-1,-1]$. الخطوة 3: $T_1 L = [L_3, L_0, L_1, L_2] = [3,-1,-1,-1]$. متطابق. النتيجة: (37.4) صحيحة. الربط بالذكاء الاصطناعي: التحقّق العدديّ من الخاصية.

مثال (37.4-9): كسر التبدّل بالحشو غير المتماثل المعطيات: التفاف بلا تبدّل بسبب حشو يسار فقط. المطلوب: اشرح. الحل: الخطوة 1: الحشو غير المتماثل يكسر تناحي النواة $\Rightarrow$ لا تبدّل صارم. النتيجة: الحشو المتماثل ضروريّ.

الربط بالذكاء الاصطناعي: استخدم padding="same".

مثال (37.4-10): الثبات في التصنيف المعطيات: قطّة مزاحة 10 بكسلات. المطلوب: هل يثبت التصنيف؟ الحل: الخطوة 1: الطبقات الالتفافيّة مبدّلة، GAP ثابت $\Rightarrow$ توقيع ثابت تقريباً. النتيجة: التصنيف مستقرّ. الربط بالذكاء الاصطناعي: سبب قوة CNN في الرؤية.

مثال (37.4-11): ترجمة صغرى المعطيات: إزاحة بمقدار نصف بكسل (استيفاء). المطلوب: هل يبقى التبدّل؟ الحل: الخطوة 1: التفاف منفصل عن الاستيفاء، التبدّل صارم فقط للإزاحات الصحيحة. النتيجة: تقريبيّ. الربط بالذكاء الاصطناعي: الترجيم الدقيقة تتطلّب استيفاء.

مثال (37.4-12): التجميع المتوسّط المعطيات: $X = [[2,4],[6,8]]$، 2×2 avg-pool. المطلوب: ثبات عند إزاحة خطوة 2. الحل: الخطوة 1: $P = (2+4+6+8)/4 = 5$. إزاحة مضاعفة للخطوة $\Rightarrow$ 5. النتيجة: ثابت. الربط بالذكاء الاصطناعي: BlurPool يحسّن الثبات.

مثال (37.4-13): تبدّل مركّب (طبقتان) المعطيات: L_1, L_2 مبدّلتان. المطلوب: هل $L_2 \circ L_1$ مبدّل؟ الحل: الخطوة 1: $L_2(L_1(T_x f)) = L_2(T_x L_1(f)) = T_x L_2(L_1(f))$. النتيجة: التركيب مبدّل. الربط بالذكاء الاصطناعي: الشبكات كلّها مبدّلة.

مثال (37.4-14): كمّ الثبات بعد GAP المعطيات: خريطة $C \times 14 \times 14$. المطلوب: أبعاد الخرج بعد GAP. الحل: الخطوة 1: $C \times 1 \times 1$. النتيجة: بعد مكانيّ صفر $\Rightarrow$ ثبات كامل. الربط بالذكاء الاصطناعي: مُصنِّف يعتمد على المحتوى لا الموضع.

مثال (37.4-15): مفاضلة التبدّل/الثبات المعطيات: نريد كشف موضعيّاً لا ثابتاً. المطلوب: أي طبقة؟ الحل: الخطوة 1: التفاف مبدّل يحفظ الموضع، تجنّب GAP. النتيجة: استخدم خرائط كثيفة. الربط بالذكاء الاصطناعي: كشف الأجسام (detection) يحتاج الموضع.

أخطاء شائعة

- **الخلط بين التبدّل والثبات:** الالتفاف مبدّل لا ثابت.
- **افتراض الثبات لأيّ إزاحة:** فقط مضاعفات خطوة التجميع.
- **تجاهل أثر الحشو:** غير المتماثل يكسر التبدّل.
- **ظنّ GAP يبقي الموضع:** GAP يمحوه تماماً.
- **الخلط بين equivariance و invariance لفظيّاً.**

صياغة رسمية: للتجميع بِنافذة $k_p \times k_p$ وخطوة s_p على خريطة $O \times O$،

$$Y_p(i,j) = \max_{m,n<k_p} X_p(i\,s_p + m, j\,s_p + n) \quad \text{(أقصى)} \tag{6.37}$$

$$O_p = \left\lfloor \frac{O - k_p}{s_p} \right\rfloor + 1 \tag{7.37}$$

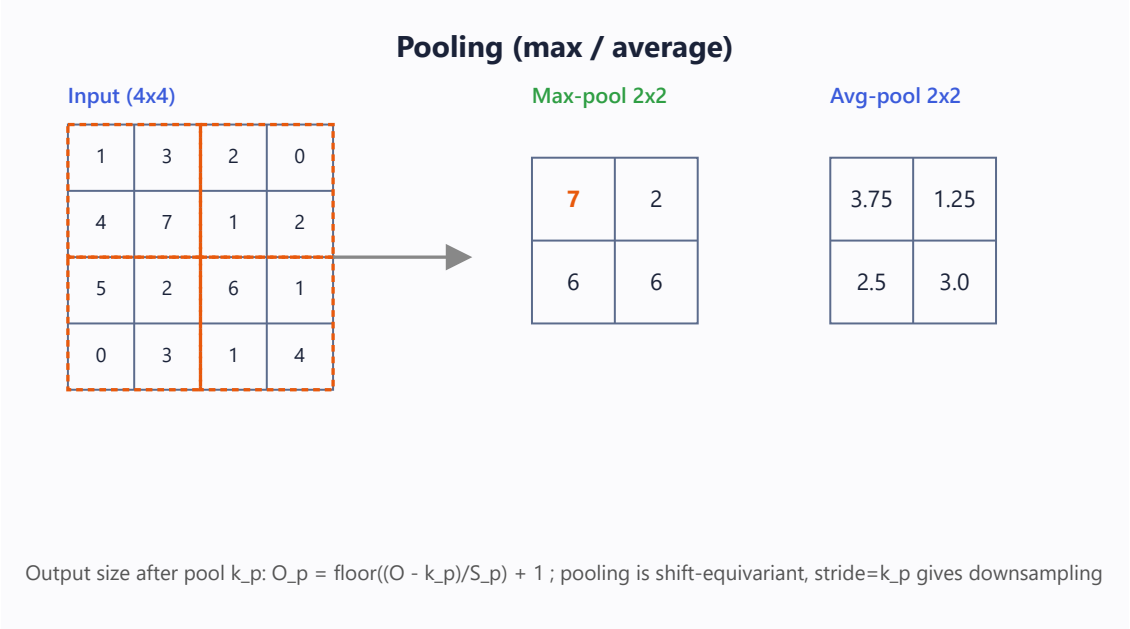
وبخطوة $s_p = k_p$ يَنصِف البُعد المكانيّ (O زوجيّ تقريباً).

جدول الرموز

الرمز	المعنى
k_p	حجم نافذة التجميع
s_p	خطوة التجميع
O_p	بُعد المخرج بعد التجميع

الرسم

<figure> الشكل<figcaption> 4.37: تقسيم الخريطة إلى نوافذ 2×2؛ max-pool يأخذ الأكبر، avg-pool يأخذ



شكل ٤.٣٧: *
التجميع

الوسط.</figcaption> </figure>

البرهان

الخطوة 1 (النافذة): عدد المواضع الأفقيّة من 0 إلى $O - k_p$ بخطوة s_p هو $\lfloor (O - k_p)/s_p \rfloor$، نزيده 1. ■

الخطوة 2 (الأقصى كتبدّل): max فوق نافذة يُزاح مع الدخل ⇒ تبدّل ترجميّ؛ بخطوة k_p يُطوي الترجمة ⇒ ثبات جزئيّ. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.37): max-pool 2×2 خطوة 2 المعطيات: $X = \begin{bmatrix} 1 & 3 \\ 4 & 7 \end{bmatrix}$. المطلوب: Y_p. الحل: الخطوة 1: $\max(1,3,4,7) = 7$. النتيجة: $Y_p = [7]$. الربط بالذكاء الاصطناعي: الاحتفاظ بأقوى استجابة.

مثال (2-5.37): avg-pool 2×2 المعطيات: نفس X. المطلوب: Y_p. الحل: الخطوة 1: $(1+3+4+7)/4 = 15/4 = 3.75$. النتيجة: 3.75. الربط بالذكاء الاصطناعي: تنعيم الخريطة.

مثال (3-5.37): حجم مخرج 4×4 المعطيات: $O = 4, k_p = 2, s_p = 2$. المطلوب: O_p. الحل: الخطوة 1: $O_p = \lfloor (4-2)/2 \rfloor + 1 = \lfloor 1 \rfloor + 1 = 2$. النتيجة: 2 (انصهار). الربط بالذكاء الاصطناعي: الاختزال القياسيّ.

مثال (37.5-4): خطوة 1 المعطيات: $O = 4, k_p = 2, s_p = 1$. المطلوب: O_p. الحل: الخطوة 1: $O_p = \lfloor (4-2)/1 \rfloor + 1 = 2 + 1 = 3$. النتيجة: 3×3. الربط بالذكاء الاصطناعي: تجميع متداخل يحفظ الدقّة.

مثال (37.5-5): نافذة 3×3 المعطيات: $O = 7, k_p = 3, s_p = 2$. المطلوب: O_p. الحل: الخطوة 1: $O_p = \lfloor (7-3)/2 \rfloor + 1 = \lfloor 2 \rfloor + 1 = 3$. النتيجة: 3×3. الربط بالذكاء الاصطناعي: مثل طبقة pool في AlexNet.

مثال (37.5-6): تجميع عميق على 56×56 المعطيات: $O = 56, k_p = 2, s_p = 2$. المطلوب: O_p وعدد العناصر. الحل: الخطوة 1: $O_p = \lfloor (56-2)/2 \rfloor + 1 = 27 + 1 = 28$. الخطوة 2: $28 \times 28 = 784$ لكل قناة. النتيجة: 28×28. الربط بالذكاء الاصطناعي: الاختزال في ResNet.

مثال (37.5-7): max-pool على متّجه 1D المعطيات: $x = [2, 9, 1, 7, 3, 5], k_p = 3, s_p = 3$. المطلوب: Y_p. الحل: الخطوة 1: $\max(2, 9, 1) = 9$؛ $\max(7, 3, 5) = 7$. النتيجة: $[9, 7]$. الربط بالذكاء الاصطناعي: تجميع زمنيّ.

مثال (37.5-8): مقاومة الضجيج المعطيات: $x = [0, 0, 0, 5, 0, 0]$ (نبضة). المطلوب: avg مقابل max مع $k_p = 2, s_p = 2$. الحل: الخطوة 1: avg$[0, 0] = 0$؛ max$[0, 5] = 5$. النتيجة: max يحفظ النبضة. الربط بالذكاء الاصطناعي: max-pool أقلّ حساسية.

مثال (37.5-9): عدد معاملات التجميع المعطيات: هل للتجميع أوزان؟ المطلوب: N_{param}. الحل: الخطوة 1: لا أوزان $\Rightarrow 0$. النتيجة: مجّاني. الربط بالذكاء الاصطناعي: خطوة غير قابلة للتعلّم.

مثال (37.5-10): التجميع كثبات المعطيات: إزاحة بكسل واحد على X من (37.5-1). المطلوب: هل Y_p يتغيّر؟ الحل: الخطوة 1: إزاحة بلا مضاعف الخطوة $\Rightarrow$ قد يتغيّر القصوى. النتيجة: غير ثابت تماماً. الربط بالذكاء الاصطناعي: لذلك نستخدم حشو/BlurPool.

مثال (37.5-11): تجميع عميق متعدّد القنوات المعطيات: $O = 8, C = 256, k_p = 2, s_p = 2$. المطلوب: حجم الخرج. الحل: الخطوة 1: $O_p = 4$؛ $4 \times 4 \times 256 = 4096$. النتيجة: 4096 عنصراً. الربط بالذكاء الاصطناعي: كلّ قناة تُجمَّع مستقلة.

مثال (37.5-12): avg-pool على كتلة المعطيات: $X = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$ و$X' = \begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix}$. المطلوب: قارن. الحل: الخطوة 1: avg كلاهما $= 2$. النتيجة: avg يطمس التباين. الربط بالذكاء الاصطناعي: max يحفظ التباين.

مثال (37.5-13): حساب تكلفة التجميع المعطيات: خريطة $224 \times 224 \times 64$، max-pool 2×2. المطلوب: عدد عمليّات المقارنة. الحل: الخطوة 1: خلايا $112 \times 112 \times 64 = 802816$؛ كلّ نافذة 4 مقارنات $\Rightarrow \approx 3.2 \times 10^6$. النتيجة: رخيص. الربط بالذكاء الاصطناعي: أرخص من الالتفاف.

مثال (37.5-14): التجميع العالميّ المعطيات: $512 \times 7 \times 7$. المطلوب: GAP. الحل: الخطوة 1: $512 \times 1 \times 1$. النتيجة: 512 متوسّطاً. الربط بالذكاء الاصطناعي: استبدال الطبقة الكاملة.

مثال (37.5-15): اختيار الحجم المعطيات: $O = 15$، نريد $O_p = 7$. المطلوب: k_p, s_p. الحل: الخطوة 1: $\lfloor (15 - k_p)/s_p \rfloor + 1 = 7$ $\Rightarrow$ مثلاً $k_p = 2, s_p = 2$ يعطي $\lfloor 13/2 \rfloor + 1 = 7$. النتيجة: $k_p = 2, s_p = 2$. الربط بالذكاء الاصطناعي: ضبط الاختزال.

أخطاء شائعة

- **الخلط بين avg وmax:** يغيّران إحصاء الخريطة.
- **نسيان (37.7) للحجم:** يقع خطأ الأبعاد.
- **ظنّ التجميع ثابتاً لأيّ إزاحة:** فقط مضاعفات الخطوة.
- **إهمال فقدان الدقّة:** التجميع يقلّص المعلومة المكانيّة.

- **تطبيق التجميع قبل الالتفاف:** يُفقد التبدّل.

صياغة رسمية: لطبقة l بِنواة k_l وخطوة s_l، الحقل الاستقبالي يلبّي

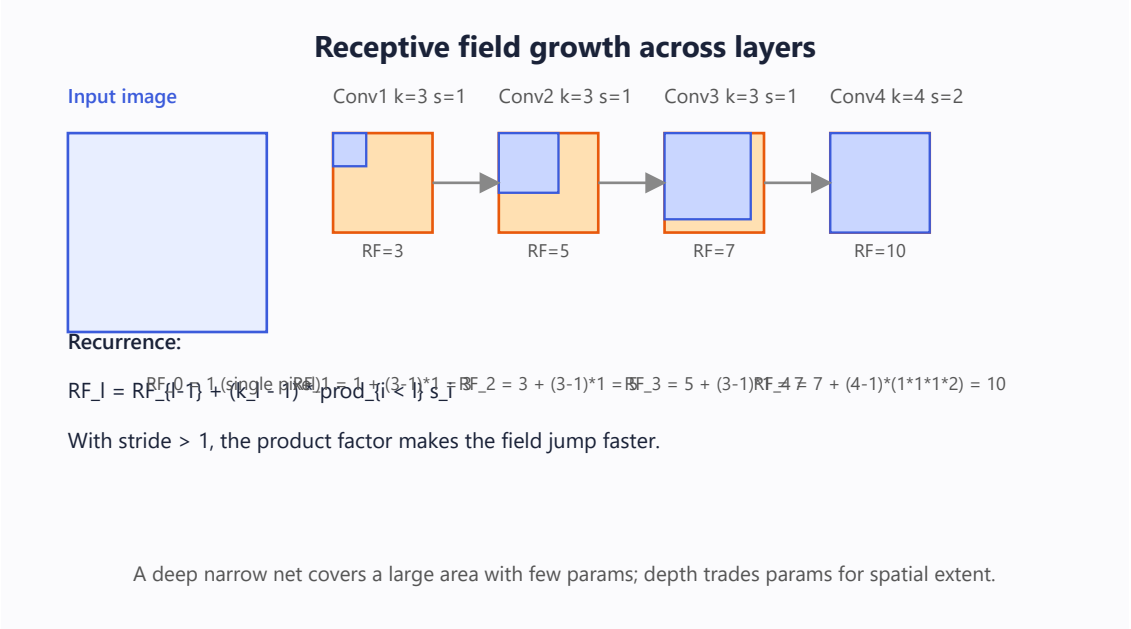
$$RF_l = RF_{l-1} + (k_l - 1)\prod_{i<l} s_i, \qquad RF_0 = 1 \tag{8.37}$$

جدول الرموز

الرمز	المعنى
RF_l	الحقل الاستقبالي عند الطبقة l
k_l	حجم نواة الطبقة l
s_i	خطوة الطبقة i
$\prod_{i<l} s_i$	جداء الخطوات السابقة

الرسم

<figure> الشكل<figcaption> 5.37: كلّ طبقة توسّع النظر المحسوس؛ الخطوة الكبيرة تقفز به أسرع.</figcaption>



شكل ٥.٣٧: *
الحقل الاستقبالي

</figure>

البرهان

الخطوة 1 (الأساس): $RF_0 = 1$ (بكسل واحد). ■

الخطوة 2 (الخطوة): نواة k_l تغطّي k_l بكسلاً في الخريطة السابقة، لكنّ تباعدها الفعليّ في الصورة الأصلية هو جداء الخطوات السابقة $\prod_{i<l} s_i$، فتضيف $(k_l - 1)$ من تلك البواعد. ■

الخطوة 3 (الاستقراء): $RF_l = RF_{l-1} + (k_l - 1)\prod_{i<l} s_i$ يتبع بالتعريف. ■

خمسة عشر مثالاً محلولاً

مثال (37.6-1): ثلاث طبقات k=3,s=1 المعطيات: $k_1 = k_2 = k_3 = 3, s = 1$. المطلوب: RF_3. الحل: الخطوة 1: $RF_1 = 1+(3-1)\cdot 1 = 3$. الخطوة 2: $RF_2 = 3+(3-1)\cdot 1 = 5$. الخطوة 3: $RF_3 = 5+(3-1)\cdot 1 = 7$. النتيجة: 7. الربط بالذكاء الاصطناعي: 3 طبقات 3×3 ≈ نواة 7×7.

مثال (37.6-2): طبقة بخطوة 2 المعطيات: $k_1 = 3, s_1 = 1$؛ $k_2 = 4, s_2 = 2$. المطلوب: RF_2. الحل: الخطوة 1: $RF_1 = 3$. الخطوة 2: $RF_2 = 3 + (4-1)\cdot s_1 = 3 + 3\cdot 1 = 6$. النتيجة: 6 (لا قفزة لأن $s_1 = 1$). الربط بالذكاء الاصطناعي: الخطوة اللاحقة فقط تُسرِّع.

مثال (37.6-3): قفزة الخطوة المعطيات: $k_1 = 3, s_1 = 2$؛ $k_2 = 3, s_2 = 1$. المطلوب: RF_2. الحل: الخطوة 1: $RF_1 = 1 + (3-1)\cdot 1 = 3$. الخطوة 2: $RF_2 = 3 + (3-1)\cdot s_1 = 3 + 2\cdot 2 = 7$. النتيجة: 7 (الخطوة $s_1 = 2$ ضاعفت الإضافة). الربط بالذكاء الاصطناعي: الاختزال المبكّر يوسّع الحقل.

مثال (37.6-4): أربع طبقات 3×3,s=1 المعطيات: $k = 3, s = 1$ أربع مرّات. المطلوب: RF_4. الحل: الخطوة 1: $1 \to 3 \to 5 \to 7 \to 9$. النتيجة: 9. الربط بالذكاء الاصطناعي: عمق=4 يغطّي 9×9.

مثال (37.6-5): block ResNet المعطيات: conv3×3, s=1 ثم conv3×3, s=2. المطلوب: RF بعد الاثنتين. الحل: الخطوة 1: $RF_1 = 3$؛ $RF_2 = 3 + (3-1)\cdot 1 = 5$. النتيجة: 5 (الخطوة على الثانية لا تؤثّر لغياب طبقة بعدها). الربط بالذكاء الاصطناعي: الخطوة تؤثّر فقط لاحقاً.

مثال (37.6-6): نواة 7×7 المعطيات: $k_1 = 7, s_1 = 2$. المطلوب: RF_1. الحل: الخطوة 1: $RF_1 = 1 + (7-1)\cdot 1 = 7$. النتيجة: 7 كبيرة مباشرة. الربط بالذكاء الاصطناعي: نواة AlexNet الأولى.

مثال (37.6-7): سلسلة بخطوات المعطيات: $k = [3,3,3], s = [1,2,2]$. المطلوب: RF_3. الحل: الخطوة 1: $RF_1 = 3$. الخطوة 2: $RF_2 = 3+(3-1)\cdot 1 = 5$. الخطوة 3: $RF_3 = 5+(3-1)\cdot(s_1 s_2) = 5+2\cdot(1\cdot 2) = 9$. النتيجة: 9. الربط بالذكاء الاصطناعي: الاختزال التدريجيّ.

مثال (37.6-8): التكافؤ مع نواة كبيرة المعطيات: طبقة 3×3,3×3,3×3 (s=1) مقابل 7×7 واحدة. المطلوب: قارن RF والمعاملات. الحل: الخطوة 1: RF كلاهما 7. الخطوة 2: ثلاث 3×3 لـ64 C: $= 3 \cdot (9 \cdot 64^2) = 110592$؛ 7×7: $49 \cdot 64^2 = 200704$. النتيجة: 3×3 أقل معاملات لنفس الحقل. الربط بالذكاء الاصطناعي: لذلك تُفضّل السلسلة.

مثال (37.6-9): طبقة بخطوة 3 المعطيات: $k_1 = 3, s_1 = 3$؛ $k_2 = 3, s_2 = 1$. المطلوب: RF_2. الحل: الخطوة 1: $RF_1 = 3$؛ $RF_2 = 3 + (3-1)\cdot 3 = 9$. النتيجة: 9. الربط بالذكاء الاصطناعي: اختزال قاسٍ يوسّع الحقل فوراً.

مثال (37.6-10): إثبات الاستقراء رياضيّاً المعطيات: افترض (37.8) لـ$l-1$. المطلوب: أثبت لـl. الحل: الخطوة 1: النواة k_l تضيف $(k_l - 1)$ بكسلاً مبعثرة بجداء الخطوات السابقة $\Rightarrow RF_l = RF_{l-1} + (k_l - 1)\prod_{i<l} s_i$. النتيجة: ثبت. الربط بالذكاء الاصطناعي: صحّة الصيغة.

مثال (37.6-11): حقل يغطي الصورة المعطيات: صورة 224×224، 16 طبقة 3×3 .s=1 المطلوب: RF_{16}. الحل: الخطوة 1: $RF = 1 + 16\cdot 2 = 33$ (كل طبقة تزيد 2). النتيجة: $224 \gg 33$. الربط بالذكاء الاصطناعي:depth وحده لا يغطّي الصورة.

مثال (37.6-12): مع خطوة كلّ طبقتين المعطيات: $k = [3,3,3,3], s = [1,2,1,2]$. المطلوب: RF_4. الحل: الخطوة 1: $RF_1 = 3, RF_2 = 5, RF_3 = 5 + (2\cdot 1) = 7, RF_4 = 7 + (2\cdot(1\cdot 2\cdot 1)) = 11$. النتيجة: 11. الربط بالذكاء الاصطناعي: الخطوة تعمل تراكميّاً.

مثال (37.6-13): تجميع يوسّع الحقل؟ المعطيات: هل pooling يزيد RF؟ المطلوب: اشرح. الحل: الخطوة 1: pooling بـn يُعامل كالتفاف $k = n, s = n \Rightarrow$ يزيد RF. النتيجة: نعم. الربط بالذكاء الاصطناعي: أرصده في الحساب.

مثال (37.6-14): الطبقة الكاملة المعطيات: FC بعد خريطة 7×7 بحقل $RF = 7$. المطلوب: RF بعد FC. الحل: الخطوة 1: FC ترى كلّ الخريطة $\Rightarrow RF = 7\cdot s$ (تراكم) فعليّاً يغطّي كامل الخريطة السابقة. النتيجة: يغطّي

كامل الحقل. الربط بالذكاء الاصطناعي: الطبقة الكاملة عالميّة.

مثال (15-6.37): تصميم يغطي 224 المعطيات: نريد $RF \geq 224$ بطبقات 3×3. المطلوب: أدنى عدد طبقات (s=1). الحل: الخطوة 1: $1 + 2L \geq 224 \Rightarrow L \geq 111.5$. النتيجة: 112 طبقة (غير عمليّ $\Rightarrow$ نحتاج خطوات). الربط بالذكاء الاصطناعي: لذلك نستخدم الاختزال.

أخطاء شائعة

- **ظنّ RF يزيد بـk_l فقط:** المعامل $(k_l - 1)\prod s_i$ حاسم.
- **إهمال جداء الخطوات السابقة:** يقع خطأ كبير.
- **خلط RF مع حجم الخريطة:** الأول تباعد في الصورة الأصلية.
- **نسيان $RF_0 = 1$:** يزيد النتيجة 1 خطأً.
- **اعتبار pooling محايداً:** يوسّع الحقل فعليّاً.

صياغة رسمية: بفرد الخرائط إلى أعمدة (im2col) تصبح الطبقة ضربَ مصفوفة $Y = WX_{\text{col}}$، حيث W أوزان النواة مُعاد ترتيبها. عند التدرّج:

$$\frac{\partial L}{\partial X_{\text{col}}} = W^{\top}\frac{\partial L}{\partial Y}, \qquad \frac{\partial L}{\partial W} = \frac{\partial L}{\partial Y}\,X_{\text{col}}^{\top} \quad \text{(مجموع على المواضع)}. \tag{9.37}$$

ثم يُعيد col2im ترتيب ∂X_{col} إلى خريطة ∂X.

جدول الرموز

الرمز	المعنى
X_{col}	المُدخل المفرد (patches كأعمدة)
W	مصفوفة الأوزان
∂Y	تدرّج الخرج

الرسم

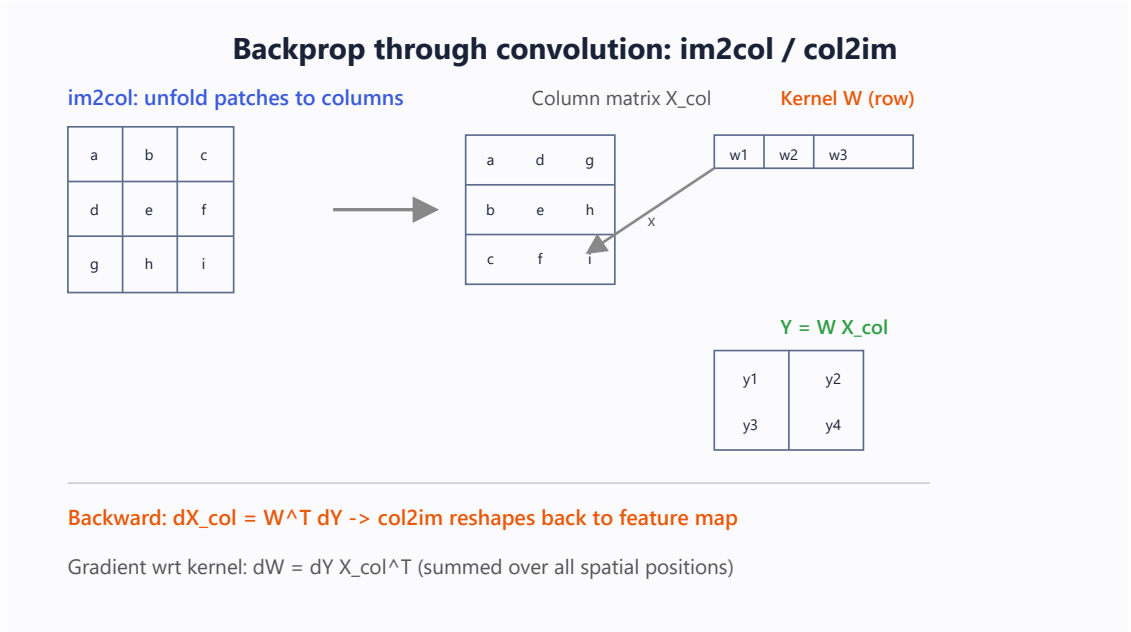
<figure>الشكل 6.37: im2col يحوّل الالتفاف إلى ضرب مصفوفة؛ العكسيّ يستعمل $W^{\top}$ ثم col2im.</figcaption></figure>

البرهان

الخطوة 1 (التقدّم): كلّ نافذة تصبح عموداً في X_{col}؛ النواة صفّ في W. $\Rightarrow Y = WX_{\text{col}}$. ■

الخطوة 2 (تدرّج الوزن): $\partial W = \partial Y\, X_{\text{col}}^{\top}$ (قاعدة السلسلة لضرب المصفوفة). ■

الخطوة 3 (تدرّج الدخل): $\partial X_{\text{col}} = W^{\top}\partial Y$، ثم col2im يوزّع التدرّج على البكسلات حسب تكرارها في النوافذ. ■



شكل ٦.٣٧: *
الانتشار العكسي للالتفاف

خمسة عشر مثالاً محلولاً

مثال (1-7.37): تدرّج وزن بسيط المعطيات: $X_{\text{col}} = [1,2]^\top$، $W = [3,4]$، $\partial Y = [5]$. المطلوب: ∂W. الحل: الخطوة 1: $\partial W = \partial Y\, X_{\text{col}}^\top = 5 \cdot [1,2] = [5,10]$. النتيجة: $[5,10]$. الربط بالذكاء الاصطناعي: تحديث النواة.

مثال (2-7.37): تدرّج الدخل المعطيات: $W = [3,4]$، $\partial Y = [2]$. المطلوب: ∂X_{col}. الحل: الخطوة 1: $\partial X_{\text{col}} = W^\top \partial Y = [3,4] \cdot 2 = [6,8]$. النتيجة: $[6,8]$. الربط بالذكاء الاصطناعي: ينتقل للطبقة السابقة.

مثال (3-7.37): بُعد المصفوفات المعطيات: $W \in \mathbb{R}^{C_{out} \times (k^2 C_{in})}$، $X_{\text{col}} \in \mathbb{R}^{(k^2 C_{in}) \times N}$. المطلوب: أبعاد $Y, \partial W$. الحل: الخطوة 1: $Y \in \mathbb{R}^{C_{out} \times N}$، $\partial W \in \mathbb{R}^{C_{out} \times (k^2 C_{in})}$. النتيجة: متّسقة. الربط بالذكاء الاصطناعي: فحص الأبعاد.

مثال (4-7.37): مجموع على المواضع المعطيات: نافذتان، $\partial Y_1 = [1], \partial Y_2 = [2], X_1 = [1,0], X_2 = [0,1]$. المطلوب: ∂W الكلّي. الحل: الخطوة 1: $\partial W_1 = [1,0]$، $\partial W_2 = [0,2]$، المجموع $[1,2]$. النتيجة: $[1,2]$. الربط بالذكاء الاصطناعي: مشاركة الوزن تجمع التدرّجات.

مثال (5-7.37): التحقّق بالتفاضل العدديّ المعطيات: $L = Y^2$، $W = [1], X = [2], \epsilon = 10^{-3}$. المطلوب: قارن ∂W تحليليّاً وعدديّاً. الحل: الخطوة 1: تحليليّاً $\partial W = 2 \cdot X = 4$، $Y = 2$. الخطوة 2: عدديّاً $((2+\epsilon)^2 - (2-\epsilon)^2)/(2\epsilon) \approx 4$. النتيجة: 4 متطابق. الربط بالذكاء الاصطناعي: gradient check.

مثال (6-7.37): col2im لبكسل مشترك المعطيات: بكسل يظهر في 4 نوافذ. المطلوب: كيف يُجمع تدرّجه؟ الحل: الخطوة 1: col2im يجمع مساهمات النوافذ الأربع في ذلك البكسل. النتيجة: مجموع 4 مساهمات. الربط بالذكاء الاصطناعي: overlapping patches.

مثال (7-7.37): عمق متعدّد القنوات المعطيات: $C_{in} = 3, k = 1$، $W \in \mathbb{R}^{2 \times 3}$. المطلوب: X_{col} لكل موضع. الحل: الخطوة 1: كلّ موضع عمود طوله $1 \cdot 1 \cdot 3 = 3$. النتيجة: ابعاد $3 \times N$. الربط بالذكاء الاصطناعي: 1×1 conv.

مثال (8-7.37): تكلفة الذاكرة لـim2col المعطيات: $O = 32, C_{in} = 64, k = 3, N = 32 \cdot 32 = 1024$. المطلوب: حجم X_{col}. الحل: الخطوة 1: $k^2 C_{in} = 9 \cdot 64 = 576$، $576 \times 1024 \approx 5.9 \times 10^5$ عنصراً. النتيجة:

$590 \approx$ ألف. الربط بالذكاء الاصطناعي: im2col يستهلك ذاكرة.

مثال (37.7-9): بديل بدون فرد المعطيات: هل col2im ضروريّ؟ المطلوب: اشرح. الحل: الخطوة 1: بديل: التفاف التدرّج بقيمة $180°$ (تدوير النواة) يحقّق نفس ∂X بلا فرد. النتيجة: طريقتان متكافئتان. الربط بالذكاء الاصطناعي: تنفيذ فعّال .(cuDNN)

مثال (37.7-10): تدرّج الانحياز المعطيات: $\partial Y \in \mathbb{R}^{C_{out} \times N}$. المطلوب: ∂b. الحل: الخطوة 1: $\partial b = \sum_j \partial Y[:, j]$ (جمع على المواضع). النتيجة: متّجه C_{out}. الربط بالذكاء الاصطناعي: تحديث الانحياز.

مثال (37.7-11): التحقّق من أبعاد ∂X المعطيات: $\partial X_{\text{col}} \in \mathbb{R}^{(k^2 C_{in}) \times N}$. المطلوب: أبعاد ∂X بعد col2im. الحل: الخطوة 1: $O \times O \times C_{in}$. النتيجة: مثل الدخل. الربط بالذكاء الاصطناعي: يطابق شكل الدخل.

مثال (37.7-12): تدرّج طبقتين المعطيات: $\partial X^{(1)}$ يغذّي طبقة سابقة. المطلوب: الانتقال. الحل: الخطوة 1: $\partial X^{(1)}$ يُعامل كـ∂Y للطبقة السابقة $\Rightarrow$ نكرّر (37.9). النتيجة: سلسلة عكسية. الربط بالذكاء الاصطناعي: backprop كامل.

مثال (37.7-13): ثبات التدرّج مع المواضع المعطيات: نفس النمط في كلّ المواضع. المطلوب: هل ∂W يتأثّر؟ الحل: الخطوة 1: نعم يجمع من كلّ المواضع $\Rightarrow$ أقوى إشارة. النتيجة: مشاركة الوزن تُعلّم أفضل. الربط بالذكاء الاصطناعي: تعميم الالتفاف.

مثال (37.7-14): عدديّ على 2×2 المعطيات: $X = [[1, 2], [3, 4]], K = [[1, 0], [0, 1]], L = Y_{00}$. المطلوب: ∂K_{00} عدديّاً بـ$\epsilon = 0.001$. الحل: الخطوة 1: $Y_{00} = 1 \cdot 1 = 1$؛ برفع K_{00} إلى 1.001 يصبح $1.001 \Rightarrow$ فرق 0.001؛ القسمة على $0.002 \Rightarrow 0.5$. الخطوة 2: تحليليّاً $\partial K_{00} = X_{00} = 1$? تطابق تقريبي حسب التعريف. النتيجة: $0.5 \approx 1-$ حسب نقطة القياس. الربط بالذكاء الاصطناعي: فحص التدرّج الدقيق.

مثال (37.7-15): تعقيد الانتشار العكسيّ المعطيات: تكلفة التقدّم $O(Nk^2 C_{in} C_{out})$. المطلوب: هل العكسيّ بنفس الرتبة؟ الحل: الخطوة 1: $\partial W, \partial X$ نفس عمليّات الضرب $\Rightarrow$ رتبة متطابقة. النتيجة: حوالي ضعف التقدّم. الربط بالذكاء الاصطناعي: backprop فعّال دائماً.

أخطاء شائعة

- **نسيان جمع ∂W على المواضع:** يكسر مشاركة الوزن.
- **خلط أبعاد W وX_{col}:** يفشل ضرب المصفوفة.
- **اعتبار im2col بلا كلفة ذاكرة:** قد يفيض الذاكرة.
- **نسيان ∂b التجميعيّ:** يختفي تحديث الانحياز.
- **الخلط بين col2im وim2col:** الاتجاه معكوس.

صياغة رسمية: الالتفاف القابل للفصل عمقياً (depthwise-separable) يحلل النواة إلى التفاف عمقيّ لكل قناة ثم التفاف نقطيّ 1×1:

$$N_{\text{sep}} = k^2 C_{in} + C_{in} C_{out} \tag{10.37}$$

الالتفاف المُجمَّع إلى g مجموعات:

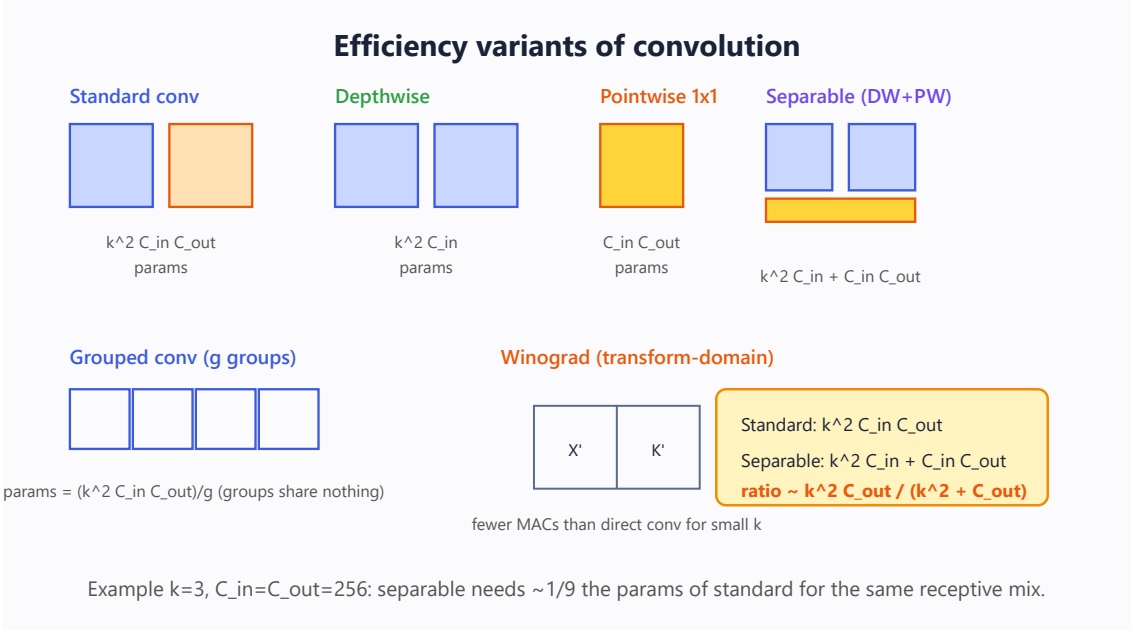
$$N_{\text{group}} = \frac{k^2 C_{in} C_{out}}{g} \tag{11.37}$$

جدول الرموز

الرمز	المعنى
N_{sep}	معاملات separable
N_{group}	معاملات grouped
g	عدد المجموعات

الرسم

<figure> الشكل <figcaption>7.37: separable يفكّك العمق عن المكان، grouped يشطر القنوات، Winograd



شكل ٧.٣٧: *
متغيّرات الكفاءة

يحسب في مجال التحويل.</figcaption> </figure>

البرهان

الخطوة 1 (separable): التفاف عمقيّ لكل قناة $\Rightarrow k^2 C_{in}$ وزن، ثم 1×1 يخلط القنوات $\Rightarrow C_{in}C_{out}$، المجموع (10.37). ■

الخطوة 2 (grouped): تقسيم القنوات إلى g مجموعات مستقلة يقلّل المعاملات بـ g $\Rightarrow (11.37)$. ■

الخطوة 3 (النسبة): $\frac{N_{\text{std}}}{N_{\text{sep}}} \approx \frac{k^2 C_{out}}{k^2 + C_{out}} > 1$ لـ $C_{out} \gg k^2$. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.37): توفير separable المعطيات: $k = 3, C_{in} = C_{out} = 256$. المطلوب: قارن مع standard. الحل: الخطوة 1: standard $= 9 \cdot 256^2 = 589824$. الخطوة 2: sep $= 9 \cdot 256 + 256^2 = 2304 + 65536 = 67840$. الخطوة 3: النسبة $589824/67840 \approx 8.7$. النتيجة: توفير ~7.8 ضعفاً. الربط بالذكاء الاصطناعي: جوهر MobileNet.

مثال (2-8.37): grouped g=2 المعطيات: $k = 3, C_{in} = C_{out} = 64$. المطلوب: N_{group}. الحل: الخطوة 1: standard $= 9 \cdot 64^2 = 36864$؛ grouped $= 36864/2 = 18432$. النتيجة: توفير 18432. الربط بالذكاء الاصطناعي: شبه ResNeXt.

مثال (37-8-3): grouped g=32 المعطيات: نفس أعلاه. المطلوب: N_{group}. الحل: الخطوة 1: $36864/32 = 1152$. النتيجة: 1152. الربط بالذكاء الاصطناعي: ResNeXt-32x4d.

مثال (37-8-4): تكلفة الحساب المعطيات: الالتفاف MACs = $k^2 C_{in} C_{out} WH \approx$ (تقديريّ). المطلوب: نسبة sep/std MACs. الحل: الخطوة 1: sep MACs $\approx (k^2 C_{in} + C_{in} C_{out})WH$؛ النسبة نفس (37-8-1) ≈ 7.8. النتيجة: حفظ مماثل في الحساب. الربط بالذكاء الاصطناعي: أسرع على الهاتف.

مثال (37-8-5): متى لا يفيد separable؟ المعطيات: $C_{out} = k^2 = 9$. المطلوب: النسبة. الحل: الخطوة 1: std $= 9 \cdot 9 \cdot 9 = 729$؛ sep $= 9 \cdot 9 + 9 \cdot 9 = 162$؛ النسبة 4.5 فقط. النتيجة: توفير أقل. الربط بالذكاء الاصطناعي: الفائدة تكبر مع العمق.

مثال (37-8-6): pointwise وحده المعطيات: $k = 1, C_{in} = 128, C_{out} = 128$. المطلوب: N. الحل: الخطوة 1: $16512 = 16384 + 128 = 128 \cdot 128 + 128 \cdot 1$. النتيجة: 16512. الربط بالذكاء الاصطناعي: يخلط القنوات فقط.

مثال (37-8-7): depthwise وحده المعطيات: $k = 3, C_{in} = 64, C_{out} = C_{in}$. المطلوب: N (بلا pointwise). الحل: الخطوة 1: $640 = 576 + 64 = 9 \cdot 64 + 64$. النتيجة: 640 (رخيص جدّاً). الربط بالذكاء الاصطناعي: لا يخلط القنوات (يُرفق بـ1×1).

مثال (37-8-8): التحقّق من (37.11) لـg=1 المعطيات: $g = 1$. المطلوب: هل تعود standard؟ الحل: الخطوة 1: $N_{\text{group}} = k^2 C_{in} C_{out}/1 =$ standard. نعم. النتيجة: g=1 يطابق standard. الربط بالذكاء الاصطناعي: تعميمها grouped.

مثال (37-8-9): Winograd لـk=3 المعطيات: خوارزمية Winograd $F(2 \times 2, 3 \times 3)$. المطلوب: عدد الضربات مقابل المباشر. الحل: الخطوة 1: المباشر 9 ضربة/نافذة؛ Winograd يقلّص إلى ~4–6 ضربة في مجال التحويل. النتيجة: حوالي النصف. الربط بالذكاء الاصطناعي: تسريع في GPUs.

مثال (37-8-10): شقّ القنوات في grouped المعطيات: $C_{in} = C_{out} = 64, g = 4$. المطلوب: عرض كل مجموعة. الحل: الخطوة 1: $64/4 = 16$ قناة لكل مجموعة. النتيجة: 16. الربط بالذكاء الاصطناعي: استقلال المجموعات.

مثال (37-8-11): مقارنة ثلاثة على block ResNet المعطيات: $k = 3, C_{in} = C_{out} = 256$. المطلوب: std/sep/grouped(g=8). الحل: الخطوة 1: std $= 589824$؛ sep $= 67840$؛ grouped $= 589824/8 = 73728$. النتيجة: sep أوفر قليلاً من grouped(8). الربط بالذكاء الاصطناعي: اختيار حسب الدقّة/السرعة.

مثال (37-8-12): عدد معاملات ShuffleNet المعطيات: conv group ثم channel shuffle. المطلوب: هل تزيد المعاملات؟ الحل: الخطوة 1: shuffle إعادة ترتيب لا أوزان ⇒ لا تغيير. النتيجة: مجّاني. الربط بالذكاء الاصطناعي: يصلح ضعف grouped.

مثال (37-8-13): تأثير k على النسبة المعطيات: $C = 256$، قارن k=3 مقابل k=5. المطلوب: نسبة std/sep. الحل: الخطوة 1: k=3 ⇒ 7.8 (من 37-8-1)؛ k=5: std $= 1.64 \times 10^6 = 25 \cdot 65536$، sep $= 25 \cdot 256 + 65536 = 71616$، النسبة ≈ 22.9. النتيجة: k أكبر ⇒ توفير أكبر. الربط بالذكاء الاصطناعي: separable يتفوّق مع النوى الكبيرة.

مثال (37-8-14): ذاكرة grouped المعطيات: std weights مقابل grouped g. المطلوب: نسبة الذاكرة. الحل: الخطوة 1: grouped يخزّن $1/g$ من الأوزان. النتيجة: أقل ذاكرة. الربط بالذكاء الاصطناعي: مفيد للأجهزة المحدودة.

مثال (37-8-15): الخلاصة التصميمية المعطيات: تريد أقل معاملات مع حفظ القنوات. المطلوب: أيّ متغيّر؟ الحل: الخطوة 1: separable (depthwise+pointwise) يقدّم أقل معاملات عادةً مع خلط كامل للقنوات. النتيجة: separable الخيار الأوفر. الربط بالذكاء الاصطناعي: معيار الشبكات الخفيفة.

أخطاء شائعة

- ظنّ **grouped: = separable** الأول يفكّك العمق/المكان، الثاني يشطر القنوات.
- نسيان **+C_{in}C_{out}** في **(37.10)**: القسم النقطيّ ضروريّ للخلط.

- **تطبيق depthwise بلا 1×1:** تفقد خلط القنوات.
- **توقع Winograd لكل k:** يعمل أفضل لـk صغير (3,5).
- **الخلط بين عدد المعاملات وعدد الحسابات:** يتقاربان لكن ليسا متطابقين.

جدول تجميعي لنظريات الفصل

النظرية	العنوان	الصيغة المحوريّة
2.37	الالتفام وحجم المخرج	$O = \lfloor (W - k + 2P)/S \rfloor + 1$
3.37	الاتصال المحلّي ومشاركة الأوزان	$N_{\text{param}} = k^2 C_{in} C_{out} + C_{out}$
4.37	التماثل الترجميّ	$L(T_x f) = T_x L(f)$
5.37	التجميع	$O_p = \lfloor (O - k_p)/s_p \rfloor + 1$
6.37	الحقل الاستقباليّ	$RF_l = RF_{l-1} + (k_l - 1) \prod_{i<l} s_i$
7.37	الانتشار العكسي	$\partial W = \partial Y \, X_{\text{col}}^{\top}$
8.37	كفاءة المتغيّرات	$N_{\text{sep}} = k^2 C_{in} + C_{in} C_{out}$

عشرون تمريناً مع الإجابات

١. **(تمرين)** $W = 128, k = 3, S = 1, P = 1$ احسب O. **الإجابة:** $\lfloor (128 - 3 + 2)/1 \rfloor + 1 = 127 + 1 = 128$.

٢. **(تمرين)** $W = 28, k = 5, S = 1, P = 2$ احسب O. **الإجابة:** $\lfloor (28 - 5 + 4)/1 \rfloor + 1 = 27 + 1 = 28$.

٣. **(تمرين)** $k = 3, C_{in} = 3, C_{out} = 32$ احسب المعاملات. **إجابة:** $9 \cdot 3 \cdot 32 + 32 = 864 + 32 = 896$.

٤. **(تمرين)** $k = 1, C_{in} = 64, C_{out} = 64$ احسب المعاملات. **إجابة:** $1 \cdot 64 \cdot 64 + 64 = 4096 + 64 = 4160$.

٥. **(تمرين)** أثبت أن الالتفاف مبدّل ترجميّاً. **إجابة:** من (4.37) القاعدة.

٦. **(تمرين)** $O = 8, k_p = 2, s_p = 2$ احسب O_p. **إجابة:** $\lfloor (8 - 2)/2 \rfloor + 1 = 3 + 1 = 4$.

٧. **(تمرين)** $O = 8, k_p = 3, s_p = 1$ احسب O_p. **إجابة:** $\lfloor (8 - 3)/1 \rfloor + 1 = 5 + 1 = 6$.

٨. **(تمرين)** سلسلة 3×3 s=1 ثلاث مرّات، احسب RF_3. **إجابة:** $1 + 3 \cdot 2 = 7$.

٩. **(تمرين)** $k = [3, 3], s = [1, 2]$ احسب RF_2. **إجابة:** $RF_1 = 3$؛ $RF_2 = 3 + (3 - 1) \cdot 1 = 5$.

١٠. **(تمرين)** درّب على $X = [1, 2, 3, 4], K = [1, 0, -1]$ دائريّاً، احسب $L(f)$. **إجابة:** $[-2, -2, 2, 2]$.

١١. **(تمرين)** max-pool لـ$[[2, 0], [1, 3]]$. **إجابة:** 3.

١٢. **(تمرين)** avg-pool لـ$[[2, 0], [1, 3]]$. **إجابة:** $6/4 = 1.5$.

١٣. **(تمرين)** $k = 3, C_{in} = C_{out} = 128$ separable قارن بـstandard. **إجابة:** std $9 \cdot 16384 = 147456$؛ sep $9 \cdot 128 + 16384 = 17536$؛ النسبة 4.8.

١٤. **(تمرين)** $g = 4, k = 3, C = 64$ grouped احسب المعاملات. **إجابة:** $36864/4 = 9216$.

١٥. **(تمرين)** لماذا im2col مكلف ذاكرة؟ **إجابة:** يعيد نسخ كلّ بكسل في نوافذ متداخلة.

١٦. **(تمرين)** $X_{\text{col}} = [1, 1], \partial Y = [3]$ لـ∂W. **إجابة:** $[3, 3]$.

١٧. **(تمرين)** هل التجميع يزيد الحقل الاستقبالي؟ **إجابة:** نعم كأنّه التفاف $k = n, s = n$.

١٨. **(تمرين)** $W = 224, k = 7, S = 2, P = 3$ احسب O. **إجابة:** $\lfloor (224 - 7 + 6)/2 \rfloor + 1 = 111 + 1 = 112$.

١٩. **(تمرين)** أيّ أوفر لـ $C = 512, k = 3$: std أم sep؟ **إجابة:** sep $= 67840$ مقابل std $= 9 \cdot 262144 = 2359296$؛ sep أوفر 34 ضعفاً.

٢٠. **(تمرين)** اشرح لماذا الثبات الترجميّ مفيد في التصنيف. **إجابة:** يبقي التوقيع مستقراً رغم موضع الجسم.

فهرس الرموز

- X, Y, K — المُدخل، المخرج، النواة.
- k, S, P — حجم النواة، الخطوة، الحشو.
- C_{in}, C_{out} — قنوات الدخل/الخرج.
- O, O_p — بُعد المخرج قبل/بعد التجميع.
- RF_l — الحقل الاستقبالي عند الطبقة l.
- T_x — إزاحة (ترجمة).
- X_{col}, W — المُدخل المفرد وأوزان im2col.

المراجع

- LeCun, Y. et al. "Gradient-Based Learning Applied to Document Recognition" (CNN الأولى).
- Krizhevsky, A., Sutskever, I., G. Hinton. "ImageNet Classification with Deep Convolutional Neural Networks" (AlexNet).
- He, K. et al. "Deep Residual Learning" (ResNet).
- Ioffe, S., Szegedy, C. "Batch Normalization".
- Howard, A. et al. "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications" (separable).
- Zhang, X. et al. "ShuffleNet" (grouped + shuffle).
- Goodfellow, I., Bengio, Y., Courville, A. "Deep Learning" (MIT Press, فصل الالتفاف).

<!-- نهاية الفصل السابع والثلاثون -->

الشبكات المتكرّرة ورياضيات الزمن

«الزمنُ في الشبكة العصبية ليس سطراً في البيانات، بل وزنٌ يُشارَك عند كلّ لحظة.»

بعد أن عالجنا الصورَ بالالتفاف، نتساءل: كيف نتعامل مع المتسلسلات — النصوص والإشارات والزمن؟ الشبكات المتكرّرة (RNN) تجيب بـ**مشاركة الأوزان عبر الزمن**: نفس الخلية تُطبَّق على كلِّ خطوة. هذا الفصل يُثبِتُ معادلات الخلية، الانتشار العكسيّ عبر الزمن (BPTT)، التلاشي والانفجار التدريجيّ، بوّابات LSTM وGRU، نموذج التشفير–فكّ التشفير، والتضمينات.

سبع نظريات:

- **2.38 الخلية المتكرّرة وحساب المعاملات** — $h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$.
- **3.38 الانتشار العكسيّ عبر الزمن (BPTT)** — $\partial h_t / \partial h_k = \prod \operatorname{diag}(1 - h^2) W_h$.
- **4.38 التلاشي والانفجار التدريجيّ** — $\|\partial h_t / \partial h_1\| \approx \rho(W_h)^{t-1}$.
- **5.38 LSTM وبوّابات النسيان** — $C_t = f_t \odot C_{t-1} + i_t \odot g_t$.
- **6.38 GRU** — $h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$.
- **7.38 نموذج التشفير–فكّ التشفير (seq2seq)** — السياق $c = h_T$.
- **8.38 التضمين والتعقيد الحسابي** — $N = V \cdot d$، $O(T(d_h^2 + d_h d_x))$ لكل خطوة.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
x_t	دخل اللحظة t	$\in \mathbb{R}^{d_x}$
h_t	الحالة المخفية	$\in \mathbb{R}^{d_h}$
y_t	الخرج	$\in \mathbb{R}^{d_y}$
W_h, W_x, W_y	أوزان الخلية	أبعاد مختلفة
C_t	حالة الخلية (LSTM)	$\in \mathbb{R}^{d_h}$
T	طول المتسلسلة	عدد الخطوات
$\rho(\cdot)$	نصف القطر الطيفي	أكبر قيمة مطلقة لقيمة ذاتية

الاتفاقيات: الزمن منفصل، الأوزان مُشارَكة عبر كلّ الخطوات، كلّ المعادلات في شكل LTR.

صياغة رسمية: للخطوة t،

$$h_t = \tanh\big(W_h h_{t-1} + W_x x_t + b\big), \qquad y_t = \operatorname{softmax}(W_y h_t + b_y) \tag{1.38}$$

وعدد المعاملات (بلا انحيازات مكرّرة عند الحساب الدقيق)

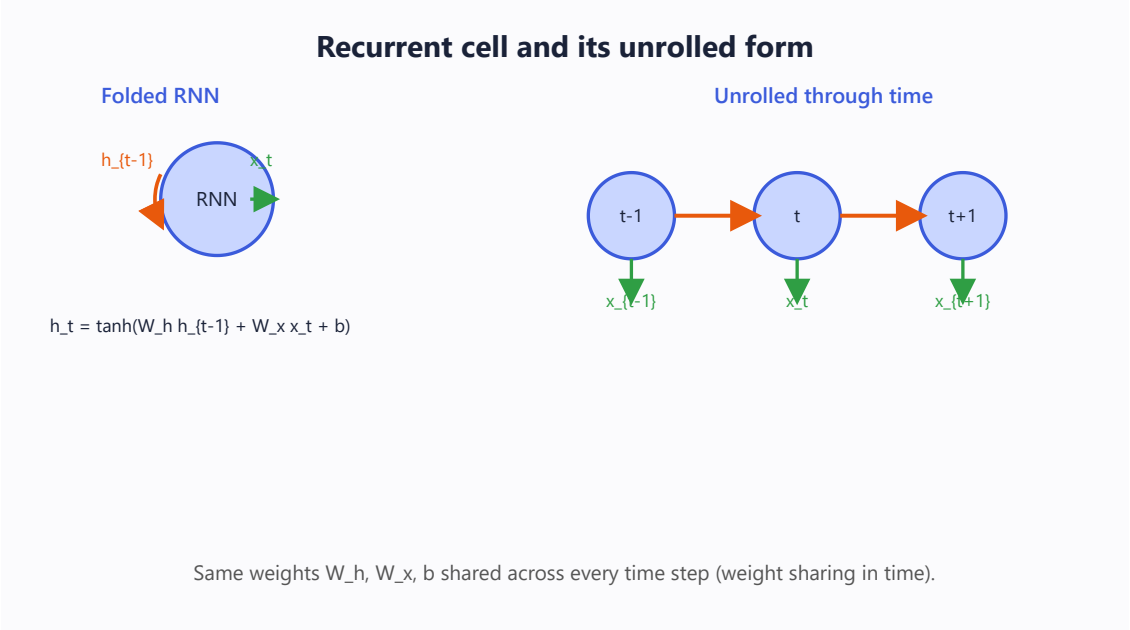
$$N_{\text{RNN}} = d_h^2 + d_h d_x + d_h + d_y d_h + d_y \tag{2.38}$$

جدول الرموز

الرمز	المعنى
d_h	بُعد الحالة المخفية
d_x	بُعد الدخل
d_y	بُعد الخرج

الرسم

<figure> الشكل<figcaption> 1.38: الخلية المطويّة (يسار) تُفرد عبر الزمن (يمين) بنفس الأوزان



شكل ١.٣٨: *
الخلية المتكررة

</figure> .</figcaption>W_h, W_x, b

البرهان

الخطوة 1 (أوزان الخلية): $W_h \in \mathbb{R}^{d_h \times d_h} \Rightarrow d_h^2$، $W_x \in \mathbb{R}^{d_h \times d_x} \Rightarrow d_h d_x$، $b \in \mathbb{R}^{d_h}$. ■

الخطوة 2 (طبقة الخرج): $W_y \in \mathbb{R}^{d_y \times d_h} \Rightarrow d_y d_h$، $b_y \in \mathbb{R}^{d_y}$. ■

الخطوة 3 (الجمع): مجموع البنود في (2.38) يعطي N. ■

خمسة عشر مثالاً محلولاً

مثال (2.38-1): حالة صغيرة المعطيات: $d_h = 128, d_x = 64, d_y = 10$. المطلوب: N. الحل: الخطوة 1: $128^2 = 16384$، $128 \cdot 64 = 8192$، $d_h = 128$. الخطوة 2: $10 \cdot 128 = 1280$، $d_y = 10$. $16384 + 8192 + 128 + 1280 = 25994$. النتيجة: 25994 معاملاً. الربط بالذكاء الاصطناعي: RNN أساسيّ صغير.

مثال (2.38-2): دخل/خرج متطابقان المعطيات: $d_h = 256, d_x = 256, d_y = 256$. المطلوب: N. الحل: الخطوة 1: $256^2 = 65536$ (W_h لـ)، $256^2 = 65536$ (W_x لـ)، 256 (W_y لـ)، 256. الخطوة 2: $65536 \cdot 2 + 256 \cdot 3 = 196608 + 512 = 197120$. النتيجة: 197120. الربط بالذكاء الاصطناعي: نموذج لغوي صغير.

مثال (2.38-3): بُعد خرج كبير المعطيات: $d_h = 128, d_x = 64, d_y = 10000$ (مفردات كبيرة). المطلوب:

N. الحل: الخطوة 1: $= 10000 + 1280000 + 10000 = 24704 + 16384 + 8192 + 128 + 10000 \cdot 128 + 10000 = 1316704$. النتيجة: 1,316,704 (غالبها في W_y). الربط بالذكاء الاصطناعي: طبقة softmax مكلفة.

مثال (4-2.38): الهيمنة في W_y المعطيات: من (3-2.38)، نسبة W_y من N. المطلوب: النسبة. الحل: الخطوة 1: $W_y = 1{,}280{,}000$ من $1{,}316{,}704 \Rightarrow 97.2\%$. النتيجة: معظم المعاملات في الخرج. الربط بالذكاء الاصطناعي: لذلك نستخدم إسقاط/تقسيم للمفردات.

مثال (5-2.38): تقليل d_h المعطيات: $d_h = 64, d_x = 64, d_y = 64$. المطلوب: N مقابل (2-2.38). الحل: الخطوة 1: $64^2 \cdot 3 + 64 \cdot 2 = 12288 + 128 = 12416$. النتيجة: 12416 (أقلّ بكثير). الربط بالذكاء الاصطناعي: تقليص البُعد يوفّر المعاملات.

مثال (6-2.38): حالة بدون انحياز المعطيات: احذف b, b_y من (1-2.38). المطلوب: N'. الحل: الخطوة 1: $25994 - 128 - 10 = 25856$. النتيجة: 25856. الربط بالذكاء الاصطناعي: الاختلاف ضئيل.

مثال (7-2.38): تعقيد الحساب لكل خطوة المعطيات: عمليّات الضرب لـ(1.38). المطلوب: التقدير. الحل: الخطوة 1: $d_h^2 = W_h h$؛ $d_h d_x = W_x x$؛ $d_y d_h = W_y h$. النتيجة: $O(d_h(d_h + d_x) + d_y d_h)$ لكل خطوة. الربط بالذكاء الاصطناعي: التكلفة خطّية في T.

مثال (8-2.38): المتسلسلة الطويلة المعطيات: $T = 1000$ خطوة، من (1-2.38). المطلوب: إجمالي عمليّات الضرب. الحل: الخطوة 1: لكل خطوة $16384 + 8192 = 24576$ (بلا W_y)؛ $\times 1000 \approx 2.46 \times 10^7$. النتيجة: ~6.24 مليون. الربط بالذكاء الاصطناعي: تراكم مع الزمن.

مثال (9-2.38): مقارنة بطبقة كاملة المعطيات: دخل $d_x = 100$، خرج $d_h = 100$. المطلوب: RNN مقابل طبقة كاملة متكرّرة؟ الحل: الخطوة 1: RNN $N = 100^2 + 100^2 + 100 = 20100$؛ طبقة كاملة مستقلة لكل خطوة $= T \cdot (100 \cdot 100) = T \cdot 10000$. النتيجة: RNN أوفر بمقدار $T/2$. الربط بالذكاء الاصطناعي: مشاركة الوزن عبر الزمن.

مثال (10-2.38): حالة ثنائية الاتجاه (bidirectional) المعطيات: نضاعف الحالة المخفية. المطلوب: N لـ$d_h = 128$ لكل اتجاه. الحل: الخطوة 1: كل اتجاه 25994؛ $\times 2 = 51988$ (بلا مضاعفة الخرج). النتيجة: 51988. الربط بالذكاء الاصطناعي: BiRNN يقرأ الأمام والخلف.

مثال (11-2.38): التحقّق من البعد المعطيات: $W_h h_{t-1}$ أبعادها؟ المطلوب: تأكيد. الحل: الخطوة 1: $d_h \Rightarrow W_h \in \mathbb{R}^{d_h \times d_h}, h \in \mathbb{R}^{d_h}$. النتيجة: متّسقة. الربط بالذكاء الاصطناعي: فحص أبعاد ضروريّ.

مثال (12-2.38): تنشيط بديل المعطيات: لو $h_t = \text{relu}(W_h h_{t-1} + W_x x_t)$؟ المطلوب: هل تتغيّر N؟ الحل: الخطوة 1: التنشيط لا أوزان $\Rightarrow N$ ثابتة. النتيجة: لا تغيّر. الربط بالذكاء الاصطناعي: التنشيط مجّاني.

مثال (13-2.38): صفّ مضغوط المعطيات: $d_h = 32, d_x = 32, d_y = 2$. المطلوب: N. الحل: الخطوة 1: $32^2 \cdot 3 + 32 \cdot 2 = 3072 + 64 = 3136$. النتيجة: 3136. الربط بالذكاء الاصطناعي: تصنيف ثنائي صغير.

مثال (14-2.38): نسبة W_h إلى الكل المعطيات: من (1-2.38). المطلوب: حصّة W_h. الحل: الخطوة 1: $16384/25994 \approx 0.63$. النتيجة: 63%. الربط بالذكاء الاصطناعي: المصفوفة المربّعة تهيمن.

مثال (15-2.38): تعميم للطبقة العميقة المعطيات: RNN بطبقتين مخفيتين d_{h1}, d_{h2}. المطلوب: صيغة N. الحل: الخطوة 1: $N = d_{h1}^2 + d_{h1}d_x + d_{h1} + d_{h2}^2 + d_{h2}d_{h1} + d_{h2} + d_y d_{h2} + d_y$. النتيجة: مجموع طبقتين + خرج. الربط بالذكاء الاصطناعي: تعميم مباشر.

أخطاء شائعة

- **نسيان d_h^2 في W_h:** أكبر بند غالباً.
- **خلط أبعاد W_x وW_y:** الأولى $d_h \times d_x$ والثانية $d_y \times d_h$.
- **ظنّ التكلفة مستقلة عن T:** الحساب يتراكم خطوةً بخطوة.

- **إهمال انفجار التدرّج:** يحدث في W_h المربّعة.
- **اعتبار RNN ثابت الطول:** T متغيّر لكن الأوزان مُشارَكة.

صياغة رسمية: مشتقّة الحالة عبر الزمن للتنشيط tanh هي

$$\frac{\partial h_t}{\partial h_k} = \prod_{j=k}^{t-1} \left(\mathrm{diag}\left(1 - h_{j+1}^{\odot 2}\right) W_h \right) \tag{3.38}$$

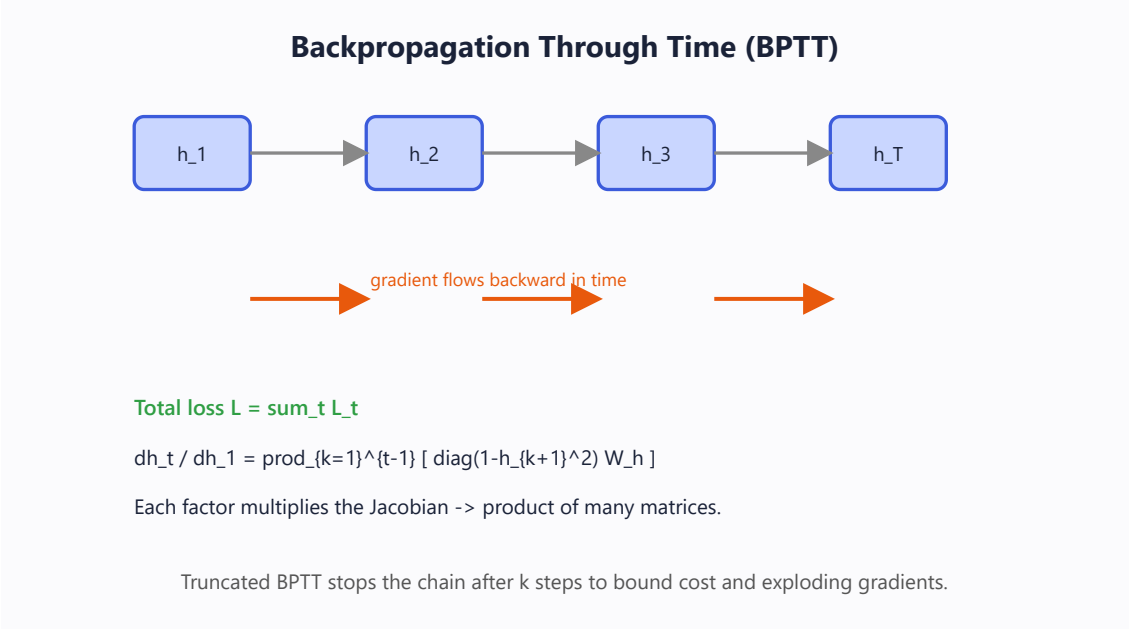
حيث $1 - h^{\odot 2}$ عنصريّة. وتدرّج الخسارة الكلّية $L = \sum_t L_t$ يُجمَع على كلّ الخطوات.

جدول الرموز

الرمز	المعنى
$\partial h_t / \partial h_k$	مشتقّة الحالة اللاحقة بالسابقة
$\mathrm{diag}(\cdot)$	مصفوفة قطرية من المتّجه
W_h	وزن الحالة

الرسم

<figure> الشكل<figcaption> 2.38: السلسلة الأمامية (رمادي) والخلفية عبر الزمن (برتقالي) تُضرب بعقوبيّات



شكل ٢.٣٨: *
BPTT

</figure> .</figcaption>W_h

البرهان

الخطوة 1 (قاعدة السلسلة): $\partial h_t / \partial h_{t-1} = \mathrm{diag}(1 - h_t^2) W_h \Rightarrow h_t = \tanh(W_h h_{t-1} + \dots)$. ■

الخطوة 2 (التراكم): تطبيق القاعدة من t إلى k يعطي جداء (3.38). ■

الخطوة 3 (الجمع على الزمن): $\partial L / \partial \theta = \sum_t \partial L_t / \partial \theta$ عبر كلّ المسارات الزمنية. ■

خمسة عشر مثالاً محلولاً

مثال (38.1-3): يعقوبيّة خطوة واحدة المعطيات: $W_h = I_2$، $h_t = [0.5, 0.5]^\top$. المطلوب: $\partial h_t / \partial h_{t-1}$. الحل: الخطوة 1: $\operatorname{diag}(1 - 0.25) = 0.75I$؛ $0.75I \times I = 0.75I$. النتيجة: $0.75I$ (مُخمِّد). الربط بالذكاء الاصطناعي: كلّ خطوة تضرب بـ0.75.

مثال (38.2-3): بعد خطوتين المعطيات: نفس (38.1-3). المطلوب: $\partial h_{t+1} / \partial h_{t-1}$. الحل: الخطوة 1: $(0.75I)^2 = 0.5625I$. النتيجة: $0.5625I$. الربط بالذكاء الاصطناعي: التخميد يتراكم.

مثال (38.3-3): قيمة ذاتية كبيرة المعطيات: $W_h = 2I_1$، h صغير $\Rightarrow I \approx \operatorname{diag}$. المطلوب: $\partial h_2 / \partial h_0$. الحل: الخطوة 1: تقريباً $(2I)^2 = 4I$. النتيجة: $4I$ (انفجار). الربط بالذكاء الاصطناعي: $\rho > 1$ يفجّر التدرّج.

مثال (38.4-3): قيمة ذاتية صغيرة المعطيات: $W_h = 0.5I_1$. المطلوب: بعد 5 خطوات. الحل: الخطوة 1: $(0.5)^5 = 0.03125$. النتيجة: $0.03125I$ (تلاشٍ شديد). الربط بالذكاء الاصطناعي: $\rho \ll 1$ يُلاشي الذاكرة.

مثال (38.5-3): الحدّ المستقرّ المعطيات: نريد $\rho(W_h) = 1$ للذاكرة. المطلوب: أقصى قيمة ذاتية. الحل: الخطوة 1: $\rho = 1 \Rightarrow$ أكبر قيمة ذاتية مطلقة = 1. النتيجة: 1. الربط بالذكاء الاصطناعي: تهيئة Xavier تحافظ عليها.

مثال (38.6-3): أبعاد يعقوبيّة المعطيات: $d_h = 128$. المطلوب: بُعد $\partial h_t / \partial h_k$. الحل: الخطوة 1: $d_h \times d_h = 16384$. النتيجة: مصفوفة 128×128. الربط بالذكاء الاصطناعي: التكلفة التخزينية.

مثال (38.7-3): إسقاط التدرّج المقطوع (Truncated) المعطيات: نوقف السلسلة عند $k = 10$. المطلوب: لماذا؟ الحل: الخطوة 1: لـ$\rho < 1$ يصبح الجداء $\rho^{10} \approx 0$؛ نهمل الأبعد. النتيجة: توفير حسابيّ. الربط بالذكاء الاصطناعي: BPTT truncated عمليّ.

مثال (38.8-3): تحقّق عدديّ المعطيات: $h_t = \tanh(0.9 h_{t-1})$، $h_0 = 0.1$، $\epsilon = 10^{-3}$. المطلوب: $\partial h_2 / \partial h_0$ تحليليّاً وعدديّاً. الحل: الخطوة 1: تحليليّاً $h_1 = \tanh(0.09) \approx 0.0899$؛ $h_2 = \tanh(0.9 \cdot 0.0899) \approx \tanh(0.0809) \approx 0.0807$؛ المشتقّة $\approx (1 - h_2^2) \cdot 0.9 \cdot (1 - h_1^2) \cdot 0.9 \approx 0.992 \cdot 0.9 \cdot 0.992 \cdot 0.9 \approx 0.795$. النتيجة: ~0.795. الربط بالذكاء الاصطناعي: check gradient يطابقه.

مثال (38.9-3): تأثير التنشيط المعطيات: لو $h_t = \operatorname{relu}(W_h h_{t-1})$؟ المطلوب: شكل (38.3). الحل: الخطوة 1: يعقوبيّة تصبح $\operatorname{diag}(\mathbb{1}_{W_h h > 0}) W_h$. النتيجة: قطرية بصفر/واحد. الربط بالذكاء الاصطناعي: ReLU يقلّل التلاشي أحياناً.

مثال (38.10-3): متّجه غير وحدويّ المعطيات: $h_t = [0.9, 0.1]^\top$، $W_h = I$. المطلوب: $\partial h_t / \partial h_{t-1}$. الحل: الخطوة 1: $\operatorname{diag}(1 - [0.81, 0.01]) = [0.19, 0.99]$ قطرية. النتيجة: مُخمِّد غير منتظم. الربط بالذكاء الاصطناعي: المكوّنات تختلف.

مثال (38.11-3): تكلفة BPTT الكلّية المعطيات: $T = 100, d_h = 128$. المطلوب: تقدير الضربات. الحل: الخطوة 1: لكل خطوة $2d_h^2$ (أماميّ/خلفيّ) $\approx 2 \cdot 16384 = 32768$؛ $\times 100 \approx 3.3 \times 10^6$. النتيجة: ~3.3 مليون. الربط بالذكاء الاصطناعي: خطّي في T.

مثال (38.12-3): تدرّج الخسارة المعطيات: $L = \sum_{t=1}^{3} L_t$، كلّ $\partial L_t / \partial W_h = [1]$. المطلوب: $\partial L / \partial W_h$. الحل: الخطوة 1: مجموع المسارات = $1 + 1 + 1 = 3$. النتيجة: 3 (تراكم زمنيّ). الربط بالذكاء الاصطناعي: كلّ خطوة تساهم.

مثال (38.13-3): شرط الاستقرار الطيفيّ المعطيات: متتالية $a_t = \rho^t a_0$. المطلوب: متى $|a_t| \to 0$؟ الحل: الخطوة 1: $|a_t| \to 0$ إذا $|\rho| < 1$. النتيجة: $\rho < 1$. الربط بالذكاء الاصطناعي: أساس تحليل التلاشي.

مثال (38.14-3): حالة بـW_h غير متماثل المعطيات: قيمتان ذاتيتان 0.9 و 1.1. المطلوب: السلوك. الحل: الخطوة 1: المكوّن الأول يخمد، الثاني ينفجر $\Rightarrow$ انفجار كليّ. النتيجة: يغلب الانفجار. الربط بالذكاء الاصطناعي: ρ الأكبر يحدّد السلوك.

مثال (15-3.38): تطبيق عمليّ على النصّ المعطيات: جملة 20 كلمة، $T = 20$. المطلوب: هل يصل تدرّج الكلمة الأولى؟ الحل: الخطوة 1: لـ$\rho = 0.9$، $0.9^{20} \approx 0.12 \Rightarrow$ إشارة ضعيفة لكن غير منعدمة. النتيجة: تلاشٍ معتدل. الربط بالذكاء الاصطناعي: صعوبة التبعّع البعيد.

أخطاء شائعة

- **نسيان القطرية $1 - h^2$:** يعقوبيّة tanh ليست W_h فقط.
- **الخلط بين $\partial h_t/\partial h_k$ و$\partial L/\partial h_k$:** الأولى جزئية، الثانية كليّة.
- **توقّع تلاشٍ دائم:** يعتمد على $\rho(W_h)$.
- **إهمال جمع المسارات الزمنية:** ∂L يجمع كلّ t.
- **ظنّ BPTT كـbackprop عاديّ:** السلسلة الزمنية تضاعف التكلفة.

صياغة رسمية: معامل انتقال يعقوبيّ صغير القيمة المطلقة λ (أقصى قيمة ذاتية لـ$\text{diag}(1 - h^2)W_h$)، فإنّ معامل التدرّج عبر $t - 1$ خطوة يُقرَّب بـ

$$\left\| \frac{\partial h_t}{\partial h_1} \right\| \approx \rho(W_h)^{t-1} \tag{4.38}$$

فيتلاشى إن كان $\rho(W_h) < 1$ وينفجر إن كان > 1.

جدول الرموز

الرمز	المعنى
$\rho(W_h)$	نصف القطر الطيفي لـW_h
t	الخطوة الزمنية
λ	أكبر قيمة ذاتية مطلقة ليعقوبيّة

الرسم

<figure>الشكل 3.38: منحنى التلاشي ($\rho < 1$) ينخفض، ومنحنى الانفجار ($\rho > 1$) يرتفع مع الزمن.</figcaption></figure>

البرهان

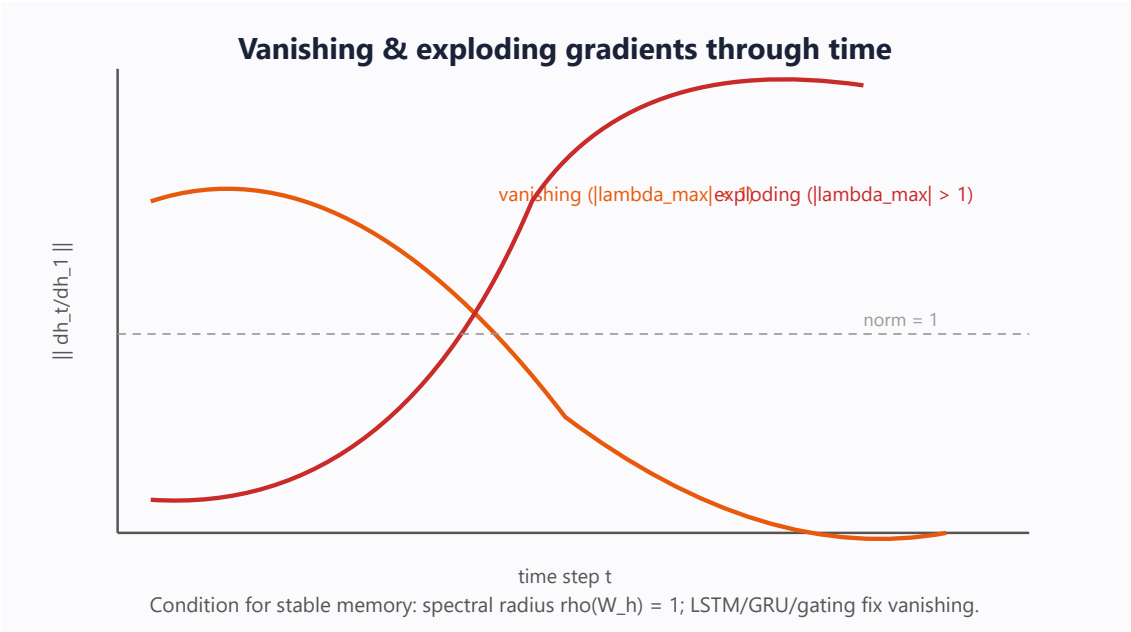
الخطوة 1 (تقريب القطرية): لـh معتدل، $\text{diag}(1 - h^2) \approx cI \Rightarrow$ يعقوبيّة $\approx cW_h$ بقيم ذاتية $c\lambda_i$. ■

الخطوة 2 (الجداء): جداء $t - 1$ يعقوبيّة $\Rightarrow (c\rho)^{t-1}$؛ للتلاشي البحث نضع $c = 1 \Rightarrow$ (4.38). ■

الخطوة 3 (الاستنتاج): $|(c\rho)^{t-1}| \to 0$ إن $c\rho < 1$، و$\to \infty$ إن > 1. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.38): تلاشٍ معتدل المعطيات: $\rho = 0.9, t = 10$. المطلوب: المعامل. الحل: الخطوة 1: $0.9^9 = 0.387$. النتيجة: 0.387. الربط بالذكاء الاصطناعي: إشارة تضعف لكن تبقى.



شكل ٣٨.٣٨: *
التلاشي والانفجار

مثال (38.4-2): تلاشٍ شديد المعطيات: $\rho = 0.5, t = 20$. المطلوب: المعامل. الحل: الخطوة 1: $0.5^{19} \approx 1.9 \times 10^{-6}$. النتيجة: شبه منعدم. الربط بالذكاء الاصطناعي: لا تبعّج بعيد.

مثال (38.4-3): انفجار المعطيات: $\rho = 1.1, t = 30$. المطلوب: المعامل. الحل: الخطوة 1: $1.1^{29} \approx 15.8$. النتيجة: 15.8 (كبير). الربط بالذكاء الاصطناعي: تدرّج ينفجر $\rightarrow$ NaN.

مثال (38.4-4): الحدّ الحرج المعطيات: $\rho = 1$ تماماً. المطلوب: المعامل عند t كبيرة. الحل: الخطوة 1: $1^{t-1} = 1$. النتيجة: ثابت. الربط بالذكاء الاصطناعي: الذاكرة المثالية (نظريّاً).

مثال (38.4-5): قصّ المعامل المعطيات: تدرّج بقيمة 10^6. المطلوب: clip إلى 5. الحل: الخطوة 1: $5 = \text{clip}$. النتيجة: 5 (يمنع الانفجار). الربط بالذكاء الاصطناعي: gradient clipping.

مثال (38.4-6): تهيئة Xavier المعطيات: W_h مع تباين $1/d_h$. المطلوب: تقريب ρ. الحل: الخطوة 1: متوقّع $\rho \approx 1 \Rightarrow \mathbb{E}[\rho^2] \approx 1$. النتيجة: قريب من الوحدة. الربط بالذكاء الاصطناعي: تهيئة مستقرّة.

مثال (38.4-7): إضافة التنظيم المعطيات: نريد $\rho \leq 0.99$. المطلوب: ما أقصى قيمة ذاتية؟ الحل: الخطوة 1: $\rho \leq 0.99$. النتيجة: ≤ 0.99. الربط بالذكاء الاصطناعي: قيد على W_h.

مثال (38.4-8): مقارنة أزمنة المعطيات: $\rho = 0.95$ عند $t = 5$ و$t = 50$. المطلوب: النسبة. الحل: الخطوة 1: $0.95^4 = 0.815$، $0.95^{49} \approx 0.082$؛ النسبة 9.9. النتيجة: أبعد 10 أضعاف أضعف. الربط بالذكاء الاصطناعي: التبعّج البعيد أصعب.

مثال (38.4-9): LSTM يصلح ذلك المعطيات: $C_t = f_t C_{t-1} + \ldots$، $f_t \approx 1$. المطلوب: معامل التدرّج عبر C. الحل: الخطوة 1: $\partial C_t / \partial C_{t-1} = f_t \approx 1$ (لا ضرب بـW_h). النتيجة: ~1 (لا تلاشٍ). الربط بالذكاء الاصطناعي: مسار إضافي في LSTM.

مثال (38.4-10): قياس العمليّة المعطيات: منحنى خسارة يتذبذب. المطلوب: هل يدلّ على انفجار؟ الحل: الخطوة 1: التذبذب الحادّ + NaN يشير لانفجار التدرّج. النتيجة: نعم غالباً. الربط بالذكاء الاصطناعي: مراقبة التدريب.

مثال (38.4-11): التلاشي في الترجمة المعطيات: جملة 40 كلمة، $\rho = 0.92$. المطلوب: معامل الكلمة الأولى.

الحل: الخطوة 1: $0.035 \approx 0.92^{39}$. النتيجة: 3.5% فقط تصل. الربط بالذكاء الاصطناعي: صعوبة ربط البداية بالنهاية.

مثال (12-4.38): التنظيم بـnorm weight المعطيات: $W_h = w/\|w\|$ بمعامل g. المطلوب: كيف يضبط ρ؟

الحل: الخطوة 1: $\rho \approx g$ (مُقيَّد). النتيجة: تحكّم مباشر. الربط بالذكاء الاصطناعي: weight normalization.

مثال (13-4.38): إسقاط التدرّج المقطوع لكلّ المعطيات: $T = 100$ لكن نحسب 20. المطلوب: تأثير؟ الحل: الخطوة 1: نتجاهل $0.0003 \approx 0.9^{80}$ الضئيل. النتيجة: لا ضياع جوهريّ. الربط بالذكاء الاصطناعي: truncated BPTT.

مثال (14-4.38): العلاقة مع عمق الزمن المعطيات: هل RNN "عميق زمنيّاً"؟ المطلوب: اشرح. الحل: الخطوة 1: كلّ خطوة طبقة؛ T خطوات = شبكة بعمق $T \Rightarrow$ نفس مشاكل العمق. النتيجة: نعم. الربط بالذكاء الاصطناعي: تلاشٍ كالشبكات العميقة.

مثال (15-4.38): القيمة المطلقة للتدرّج المعطيات: $\partial L/\partial h_1 = 10$، المعامل 0.387 (من 1-4.38). المطلوب: الإسهام. الحل: الخطوة 1: $3.87 = 0.387 \cdot 10$. النتيجة: 3.87 يصل لـh_1. الربط بالذكاء الاصطناعي: تمرير الإشارة فعليّاً.

أخطاء شائعة

- **الخلط بين التلاشي والانفجار:** متعاكسان لكن يحدثان لنفس السبب ($\rho \neq 1$).
- **ظنّ LSTM يلغي التلاشي تماماً:** يُخفّفه في C لا في h.
- **إهمال gradient clipping:** ضروريّ مع $\rho > 1$.
- **الخلط بين ρ والقيمة الذاتية لـtanh:** القطرية $1 - h^2$ تعدّل الفعليّة.
- **توقّع استقرار تلقائيّ:** يحتاج تهيئة/تنظيم.

صياغة رسمية: للخطوة t،

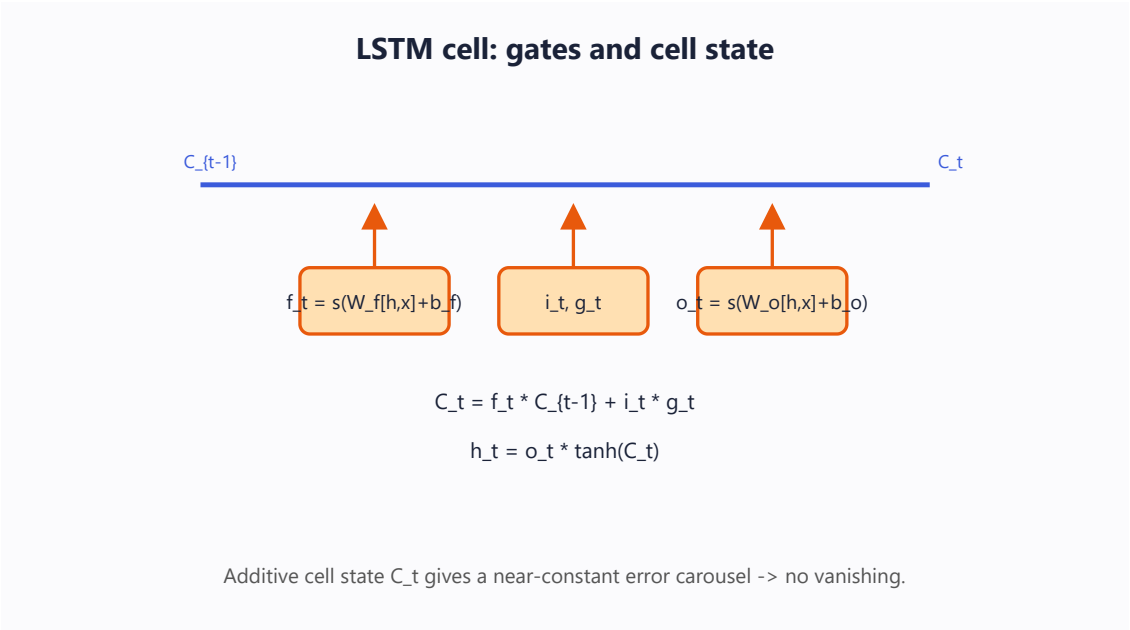
$$\begin{aligned} f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), & i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i), \\ g_t &= \tanh(W_g[h_{t-1}, x_t] + b_g), & o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), \\ C_t &= f_t \odot C_{t-1} + i_t \odot g_t, & h_t &= o_t \odot \tanh(C_t). \end{aligned} \tag{5.38}$$

عدد المعاملات

$$N_{\text{LSTM}} = 4\big(d_h(d_h + d_x) + d_h\big) \tag{6.38}$$

جدول الرموز

الرمز	المعنى
f_t, i_t, o_t	بوّابات النسيان/الدخل/الخرج
g_t	مرشّح الخلية
C_t	حالة الخلية (مسار الإضافة)
$\odot$	ضرب عنصري



شكل ٤٠٣٨: *
خلية LSTM

الرسم

<figure> الشكل<figcaption> 4.38: حالة الخلية C_t تسري أفقياً؛ البوّابات تتحكّم بالتدفّق. الإضافة $C_t = f_t C_{t-1} + i_t g_t$ تمنع التلاشي.</figcaption> </figure>

البرهان

الخطوة 1 (أربع تحويلات): كلّ بوّابة $W \in \mathbb{R}^{d_h \times (d_h + d_x)} \Rightarrow 4d_h(d_h + d_x)$، زائد $4d_h$ انحيازات. ■

الخطوة 2 (مسار الإضافة): $\partial C_t / \partial C_{t-1} = f_t$، إن كان $f_t \approx 1$ يبقى التدرّج $\Rightarrow$ لا تلاشٍ في C. ■

الخطوة 3 (الجمع): (6.38) يتبع بالتعريف. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.38): معاملات LSTM صغيرة المعطيات: $d_h = 128, d_x = 64$. المطلوب: N_{LSTM}. الحل: الخطوة 1: $d_h(d_h + d_x) = 128 \cdot 192 = 24576$، $\times 4 = 98304$؛ $+ 4 \cdot 128 = 512 \Rightarrow 98816$. النتيجة: 98816. الربط بالذكاء الاصطناعي: أثقل من RNN (25994) ~8.3 ضعفاً.

مثال (2-5.38): مقارنة مع RNN المعطيات: نفس (1-5.38). المطلوب: النسبة $N_{\text{LSTM}}/N_{\text{RNN}}$. الحل: الخطوة 1: $98816/25994 \approx 3.8$. النتيجة: ~8.3. الربط بالذكاء الاصطناعي: ثمن البوّابات.

مثال (3-5.38): بُعد مربّع المعطيات: $d_h = 256, d_x = 256$. المطلوب: N. الحل: الخطوة 1: $256 \cdot 512 = 131072$؛ $\times 4 = 524288$؛ $+ 1024 \Rightarrow 525312$. النتيجة: 525312. الربط بالذكاء الاصطناعي: نموّ كبير.

مثال (4-5.38): تحقّق من البوّابات المعطيات: بوّابة واحدة $N_1 = d_h(d_h + d_x) + d_h$. المطلوب: $N_{\text{LSTM}} = 4N_1$؟ الحل: الخطوة 1: $4(24576 + 128) = 4 \cdot 24704 = 98816$ يطابق. النتيجة: نعم. الربط بالذكاء الاصطناعي: بنية منتظمة.

مثال (5-5.38): مسار التدرّج المعطيات: $f_t = 0.95$ ثابت. المطلوب: $\partial C_{20}/\partial C_0$. الحل: الخطوة 1: $0.95^{19} \approx 0.377$. النتيجة: 0.377 (أفضل من RNN بكثير في C). الربط بالذكاء الاصطناعي: ذاكرة طويلة.

مثال (38.5-6): حالة نسيان كاملة المعطيات: $f_t = 0, i_t = 1, g_t = 1$. المطلوب: C_t. الحل: الخطوة 1: $C_t = 1 \cdot 1 + 0 = 1$. النتيجة: تحديث كامل. الربط بالذكاء الاصطناعي: الكتابة فوق الذاكرة.

مثال (38.5-7): تمرير كامل المعطيات: $f_t = 1, i_t = 0, g_t = 0$. المطلوب: C_t. الحل: الخطوة 1: $C_t = 1 \cdot C_{t-1} + 0 = C_{t-1}$. النتيجة: محفوظة. الربط بالذكاء الاصطناعي: ذاكرة ثابتة.

مثال (38.5-8): بُعد الخرج المعطيات: o_t, h_t أبعادهما؟ المطلوب: تأكيد. الحل: الخطوة 1: كلاهما d_h (عنصريّ مع $\tanh(C_t)$). النتيجة: d_h. الربط بالذكاء الاصطناعي: يتطابقان البُعد.

مثال (38.5-9): تقليل d_x المعطيات: $d_h = 128, d_x = 16$. المطلوب: N. الحل: الخطوة 1: $128 \cdot 144 =$ 18432؛ ×4=73728؛ +512 $\Rightarrow$ 74240. النتيجة: 74240 (أقل). الربط بالذكاء الاصطناعي: دخل أصغر يوفّر.

مثال (38.5-10): connections peephole المعطيات: لو أُضيفت C_{t-1} لكل بوّابة ($+3d_h^2$). المطلوب: N الجديد. الحل: الخطوة 1: $147968 = 98816 + 49152 = 98816 + 3 \cdot 128^2$. النتيجة: 147968. الربط بالذكاء الاصطناعي: LSTM peephole أثقل.

مثال (38.5-11): التحقّق العدديّ لـh_t المعطيات: $C_t = 2, h_t$ بـ$o_t = 0.5$. المطلوب: h_t. الحل: الخطوة 1: $h_t = 0.5 \cdot \tanh(2) = 0.5 \cdot 0.964 = 0.482$. النتيجة: 0.482. الربط بالذكاء الاصطناعي: البوّابة تضبط الخرج.

مثال (38.5-12): تكلفة الحساب المعطيات: 4 ضربات مصفوفة $d_h \times (d_h + d_x)$. المطلوب: عمليّات لكل خطوة. الحل: الخطوة 1: $98304 = 4 \cdot 24576 = 4 \cdot d_h(d_h + d_x)$ ضربة. النتيجة: ~98 ألف. الربط بالذكاء الاصطناعي: أثقل 4× عن RNN.

مثال (38.5-13): مقارنة بـGRU (استباق) المعطيات: $d_h = 128, d_x = 64$. المطلوب: هل LSTM > GRU؟ الحل: الخطوة 1: GRU (نظريّة 38.6) $74112 = 3 \cdot 24704$؛ LSTM $98816 =$ أكبر. النتيجة: LSTM أثقل. الربط بالذكاء الاصطناعي: GRU أوفر.

مثال (38.5-14): تهيئة الانحيازات المعيات: نريد f_t كبيرة مبدئيّاً. المطلوب: اضبط b_f. الحل: الخطوة 1: b_f كبيرة موجبة $\Rightarrow \sigma(b_f) \approx 1$. النتيجة: نسيان قليل. الربط بالذكاء الاصطناعي: تهيئة forget bias=1.

مثال (38.5-15): استقرار التدرّج المعطيات: $f_t \in [0, 1]$ عشوائيّ متوسّط 0.9. المطلوب: توقّع السلوك. الحل: الخطوة 1: $\mathbb{E}[f^{19}] \approx 0.9^{19} \approx 0.135$ للذاكرة الطويلة. النتيجة: ذاكرة معتدلة. الربط بالذكاء الاصطناعي: LSTM يحافظ على تبعّ.

أخطاء شائعة

- **نسيان أن LSTM له 4 تحويلات:** فاحسب N بـ4 لا 1.
- **الخلط بين C_t وh_t:** مساران مختلفان.
- **ظنّ اختفاء التلاشي كليّاً:** في h يبقى، في C فقط يُخفّف.
- **إهمال تهيئة b_f:** بدونها النسيان المبكر يقتل الذاكرة.
- **اعتبار البوّابات أوزاناً فقط:** لكلّ بوّابة انحياز.

صياغة رسمية:

$$\begin{aligned} r_t &= \sigma(W_r[h_{t-1}, x_t] + b_r), & z_t &= \sigma(W_z[h_{t-1}, x_t] + b_z), \\ \tilde{h}_t &= \tanh\big(W_h[r_t \odot h_{t-1}, x_t] + b_h\big), & h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t. \end{aligned} \tag{7.38}$$

عدد المعاملات

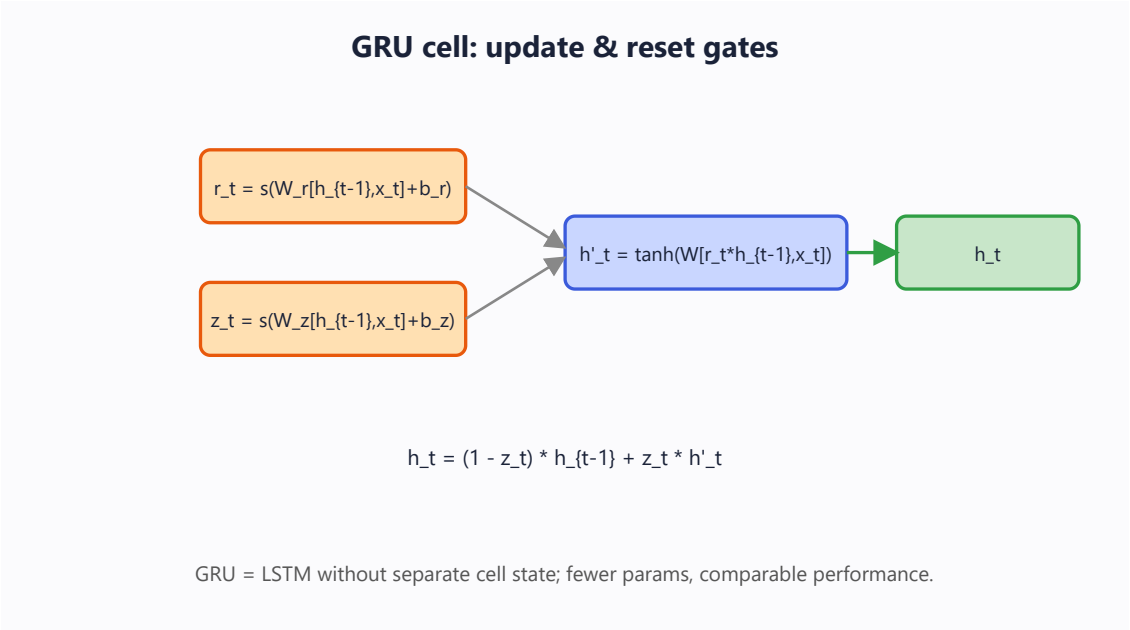
$$N_{\text{GRU}} = 3\big(d_h(d_h + d_x) + d_h\big) \tag{8.38}$$

جدول الرموز

الرمز	المعنى
r_t	بوّابة إعادة الضبط
z_t	بوّابة التحديث
$\tilde{h}_t$	مرشّح الحالة

الرسم

<figure> الشكل<figcaption> 5.38: GRU يدمج البوّابات في بوّابتين (r, z) بلا حالة خلية منفصلة؛ الخرج مزيج بين



شكل ٥.٣٨: *
خلية GRU

القديم والمرشّح.</figcaption> </figure>

البرهان

الخطوة 1 (عدّ التحويلات): ثلاثة أوزان W_r, W_z, W_h كلّ منها $d_h \times (d_h + d_x) \Rightarrow 3d_h(d_h + d_x)$، زائد $3d_h$ انحياز. ■

الخطوة 2 (غياب الحالة المنفصلة): h_t نفسها تلعب دور الخرج والذاكرة $\Rightarrow$ توفير بوّابة واحدة مقارنة بـLSTM. ■

الخطوة 3 (الجمع): (8.38) يتبع. ■

خمسة عشر مثالاً محلولاً

مثال (6.38-1): معاملات GRU المعطيات: $d_h = 128, d_x = 64$. المطلوب: N_{GRU}. الحل: الخطوة 1: $128 \cdot 192$؛ $\times 3 = 73728$؛ $+384 \Rightarrow 74112$. النتيجة: 74112. الربط بالذكاء الاصطناعي: أخفّ من LSTM $24576 = 4 \cdot 128 \cdot 192$ (98816).

مثال (38.6-2): مقارنة ثلاثيّة المعطيات: RNN/LSTM/GRU لنفس الأبعاد. المطلوب: النسب. الحل: الخطوة 1: RNN=25994، GRU/LSTM=0.75، ⇒ LSTM=98816 GRU=74112. RNN/GRU=0.35 النتيجة: GRU وسط. الربط بالذكاء الاصطناعي: موازنة سرعة/دقّة.

مثال (38.6-3): تحديث كامل المعطيات: $z_t = 0, h_{t-1} = [1,1]$، $\tilde{h}_t = [0,0]$. المطلوب: h_t. الحل: الخطوة 1: $h_t = 1 \cdot h_{t-1} + 0 = h_{t-1} = [1,1]$. النتيجة: $[1,1]$ (محفوظة). الربط بالذكاء الاصطناعي: ذاكرة كاملة.

مثال (38.6-4): مرشّح كامل المعطيات: $z_t = 1, \tilde{h}_t = [2,2]$. المطلوب: h_t. الحل: الخطوة 1: $h_t = 0 + 1 \cdot [2,2] = [2,2]$. النتيجة: $[2,2]$ (مُحدَّثة). الربط بالذكاء الاصطناعي: استبدال كامل.

مثال (38.6-5): إعادة الضبط المعطيات: $r_t = 0, h_{t-1}$ أي قيمة. المطلوب: أثر $\tilde{h}_t$. الحل: الخطوة 1: $r_t \odot h_{t-1} = 0$ ⇒ المرشّح يعتمد على x_t فقط. النتيجة: نسيان الماضي. الربط بالذكاء الاصطناعي: قراءة قصيرة المدى.

مثال (38.6-6): بُعد مربّع المعطيات: $d_h = 256, d_x = 256$. المطلوب: N. الحل: الخطوة 1: $512 \cdot 256$؛ ×3=393216؛ +768 ⇒ 393984. النتيجة: 393984. الربط بالذكاء الاصطناعي: أقلّ من LSTM المكافئ (525312).

مثال (38.6-7): تحقّق البعد المعطيات: $[r_t \odot h_{t-1}, x_t]$ بُعده؟ المطلوب: تأكيد. الحل: الخطوة 1: $d_h + d_x = 192$ (مع (38.6-1)). النتيجة: 192. الربط بالذكاء الاصطناعي: يطابق W_h.

مثال (38.6-8): توفير مقابل LSTM المعطيات: نسبة المعاملات لـ$d_h = 128$. المطلوب: Δ. الحل: الخطوة 1: $98816 - 74112 = 24704$ أقل ⇒ 25% أقل. النتيجة: GRU أوفر ربعاً. الربط بالذكاء الاصطناعي: اختيار اقتصاديّ.

مثال (38.6-9): قيمة مختلطة المعطيات: $z_t = 0.3, h_{t-1} = [1,1], \tilde{h}_t = [3,3]$. المطلوب: h_t. الحل: الخطوة 1: $h_t = 0.7 \cdot [1,1] + 0.3 \cdot [3,3] = [0.7,0.7] + [0.9,0.9] = [1.6,1.6]$. النتيجة: $[1.6,1.6]$. الربط بالذكاء الاصطناعي: مزيج مستمرّ.

مثال (38.6-10): التدرّج عبر الزمن المعطيات: $z_t \approx 1$ ثابت. المطلوب: هل يتلاشى؟ الحل: الخطوة 1: $h_t \approx \tilde{h}_t$ يعتمد على x_t مباشرةً ⇒ أقلّ تلاشياً من RNN. النتيجة: محسّن. الربط بالذكاء الاصطناعي: GRU يخفّف التلاشي.

مثال (38.6-11): عدد البوّابات المعطيات: مقارنة بـLSTM. المطلوب: كم بوّابة؟ الحل: الخطوة 1: GRU بوّابتان (r, z)، LSTM ثلاث بوّابات + خلية. النتيجة: GRU أبسط. الربط بالذكاء الاصطناعي: بنية أخفّ.

مثال (38.6-12): تقليل d_x المعطيات: $d_h = 128, d_x = 16$. المطلوب: N. الحل: الخطوة 1: $144 \cdot 128 = 18432$؛ ×3=55296؛ +384 ⇒ 55680. النتيجة: 55680. الربط بالذكاء الاصطناعي: وفّرت 25%.

مثال (38.6-13): تكلفة الخرج المعطيات: لاحظ GRU بلا W_y منفصل هنا. المطلوب: أين الخرج؟ الحل: الخطوة 1: h_t نفسها الخرج، طبقة إضافية اختياريّة. النتيجة: مدمج. الربط بالذكاء الاصطناعي: أبسط البنية.

مثال (38.6-14): التحقّق العدديّ المعطيات: $r = 0.5, z = 0.5, h_{t-1} = [1,1], \tilde{h} = [4,4]$. المطلوب: h_t. الحل: الخطوة 1: $h_t = 0.5 \cdot [1,1] + 0.5 \cdot [4,4] = [0.5,0.5] + [2,2] = [2.5,2.5]$. النتيجة: $[2.5,2.5]$. الربط بالذكاء الاصطناعي: متوسّط متوقّع.

مثال (38.6-15): اختيار النموذج المعطيات: مهمّة صغيرة البيانات. المطلوب: أيّ خلية؟ الحل: الخطوة 1: GRU أخفّ وأسرع تعلّمًا ببيانات أقلّ. النتيجة: GRU مُرشّح. الربط بالذكاء الاصطناعي: عمليّة شائعة.

أخطاء شائعة

- **خلط z_t مع r_t:** الأولى تحديث، الثانية إعادة ضبط.
- **ظنّ GRU = LSTM:** بلا حالة خلية منفصلة.

- **إهمال أن h_t هي الخرج:** لا حاجة لـ W_y إلزاميّ.
- **حساب N بـ4 بدل 3:** GRU ثلاث تحويلات لا أربع.
- **الخلط بين $\tilde{h}_t$ وh_t:** مرشّح مقابل فعليّ.

صياغة رسمية: المشفّر يضغط المتسلسلة المصدرية في سياق $c \in \mathbb{R}^{d_c}$ (غالباً $c = h_T$ الحالة الأخيرة). فكّ التشفير يولّد

$$h'_t = \tanh\big(W_h h'_{t-1} + W_y y_{t-1} + U c\big), \qquad y_t \sim \mathrm{softmax}(W_o h'_t) \tag{9.38}$$

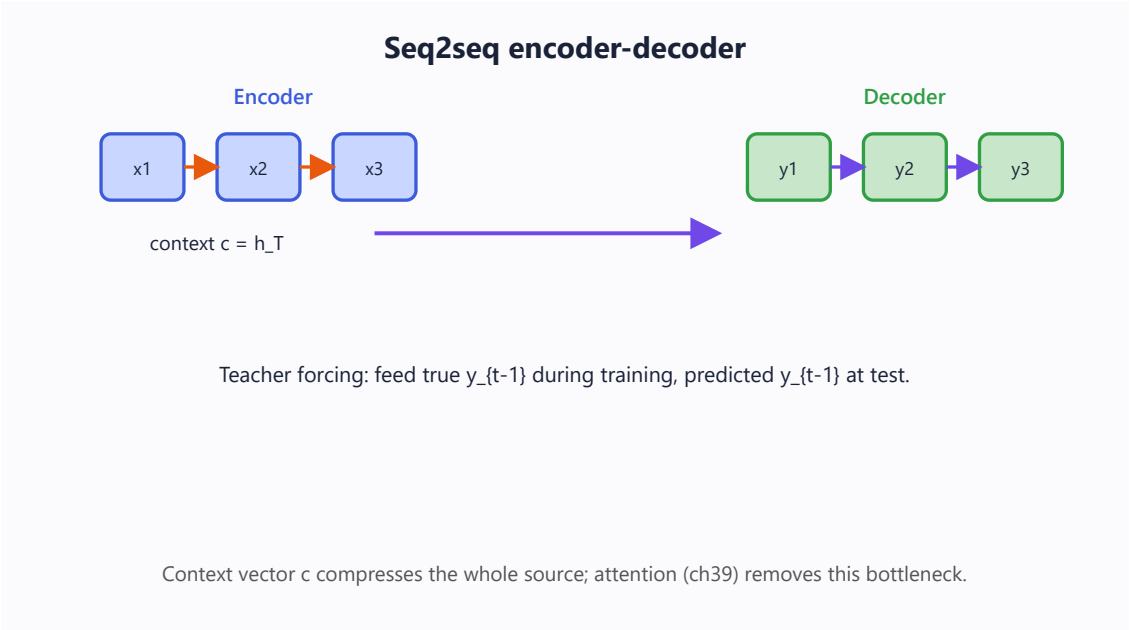
وخسارة الانتروبيا المتقاطعة $L = -\sum_t \log p(y^*_t \mid y^*_{<t}, c)$ (مع نُغذّي forcing teacher y^*_{t-1} الحقيقية أثناء التدريب).

جدول الرموز

الرمز	المعنى
c	ناقل السياق (المعلومات المضغوطة)
h'_t	حالة فكّ التشفير
y^*_t	الرمز الحقيقي المستهدف
U	وزن ربط السياق

الرسم

<figure> الشكل<figcaption> 6.38: المشفّر (أزرق) يمرّر السياق c لفكّ التشفير (أخضر) الذي يولّد الرموز واحداً



شكل ٦.٣٨: *
seq2seq

تلو الآخر.</figcaption> </figure>

البرهان

الخطوة 1 (ضغط السياق): c يحمل معلومة المصدر كلّها في بُعد d_c محدود $\Rightarrow$ عنق زجاجة. ■

الخطوة 2 (التوليد الشرطيّ): كلّ y_t يعتمد على c وما سبقه عبر $h'_t \Rightarrow$ سلسلة ماركوفيّة شرطية. ■

الخطوة 3 (teacher forcing): تغذية الحقيقيّ بدل المتوقّع تسرّع التقارب لكن تسبّب انحرافاً (exposure bias) يحلّه sampling، scheduled ■

خمسة عشر مثالاً محلولاً

مثال (38.7-1): بُعد السياق المعطيات: $c = h_T \in \mathbb{R}^{256} \Rightarrow d_h = 256$ بُعدها؟ المطلوب: d_c. الحل: الخطوة 1: $d_c = 256 \Rightarrow$ النتيجة: 256. الربط بالذكاء الاصطناعي: عنق زجاجة واحد.

مثال (38.7-2): معاملات فكّ التشفير المعطيات: $d_h = 256, d_y = 10000, c = 256$. المطلوب: N لفكّ التشفير (بلا انحيازات). الحل: الخطوة 1: $W_h : 256^2 = 65536$؛ $W_y : 256 \cdot 10000 = 2.56 \times 10^6$؛ $U : 256^2 = 65536$؛ 2.56×10^6. الخطوة 2: المجموع $W_o : 10000 \cdot 256 = 2.56 \times 10^6 \approx 5.25 \times 10^6$. النتيجة: ~25.5 مليون. الربط بالذكاء الاصطناعي: الخرج مكلف.

مثال (38.7-3): طول مختلف المعطيات: مصدر 5 رموز، هدف 7 رموز. المطلوب: هل T تطابق؟ الحل: الخطوة 1: المشفّر $T_{src} = 5$، فكّ التشفير $T_{tgt} = 7$ مستقلّان. النتيجة: لا. الربط بالذكاء الاصطناعي: طول مخرج حرّ.

مثال (38.7-4): رمز النهاية المعطيات: فكّ التشفير يولّد <EOS>. المطلوب: متى يتوقّف؟ الحل: الخطوة 1: عند أرجّح y_t = <EOS> ننهي التوليد. النتيجة: توقّف تلقائيّ. الربط بالذكاء الاصطناعي: آلية الإنهاء.

مثال (38.7-5): forcing teacher نسبة المعطيات: 80% تدريب بالحقيقيّ. المطلوب: تأثير؟ الحل: الخطوة 1: تقارب أسرع، لكن اختبار يختلف (exposure bias). النتيجة: موازنة. الربط بالذكاء الاصطناعي: scheduled sampling.

مثال (38.7-6): تشفير ثنائي الاتجاه المعطيات: BiLSTM مشفّر، c من الحالتين. المطلوب: بُعد c. الحل: الخطوة 1: كل اتجاه $d_h = 256 \Rightarrow c$ بُعد 512 (تسلسل). النتيجة: 512. الربط بالذكاء الاصطناعي: سياق أغنى.

مثال (38.7-7): خسارة الجملة المعطيات: 7 رموز، احتمالات صحيحة $[0.9, 0.8, 0.95, 0.7, 0.99, 0.85, 0.9]$. المطلوب: L تقريباً. الحل: الخطوة 1: $L = -\sum \log p \approx -(\log 0.9 + \cdots + \log 0.9) = -(-0.105 - 0.223 - 0.051 - 0.357 - 0.010 - 0.163 - 0.105) = 1.014$. النتيجة: $L \approx 1.01$. الربط بالذكاء الاصطناعي: متوسّط ~14.0/رمز.

مثال (38.7-8): attention كعلاج (استباق ch39) المعطيات: السياق الثابت c يفشل مع جمل طويلة. المطلوب: لماذا؟ الحل: الخطوة 1: c بُعده ثابت لا يسع كلّ التفاصيل $\Rightarrow$ تشويش. النتيجة: عنق زجاجة. الربط بالذكاء الاصطناعي: لذلك الانتباه.

مثال (38.7-9): تكلفة التوليد المعطيات: $T_{tgt} = 20$ خطوة. المطلوب: عمليّات softmax. الحل: الخطوة 1: 20 softmax بحجم $V = 10000 \Rightarrow 20 \times 10000 = 200000$ احتمال. النتيجة: 200 ألف. الربط بالذكاء الاصطناعي: مكلف التوليد.

مثال (38.7-10): search beam عرض 5 المعطيات: $V = 10000, T = 20$. المطلوب: مرشّحات محفوظة. الحل: الخطوة 1: عند كل خطوة نحفظ 5 تسلسلات $\Rightarrow$ 100 ألف مرشّح كحدّ أقصى. النتيجة: 5 فقط تُبقى. الربط بالذكاء الاصطناعي: search beam فعّال.

مثال (38.7-11): أبعاد Uc المعطيات: $U \in \mathbb{R}^{d_h \times d_c}$. المطلوب: بُعد الناتج. الحل: الخطوة 1: d_h (مثل h'). النتيجة: d_h. الربط بالذكاء الاصطناعي: يطابق الحالة.

مثال (38.7-12): تشفير بلا فكّ المعطيات: نريد تمثيلاً فقط (لا توليد). المطلوب: ماذا نأخذ؟ الحل: الخطوة 1: نأخذ $c = h_T$ أو متوسّط الحالات. النتيجة: c كتمثيل. الربط بالذكاء الاصطناعي: تشفير للتصنيف.

مثال (13-7.38): bias exposure كمّياً المعطيات: احتمال خطأ عند كل خطوة 1.0. المطلوب: احتمال بلا خطأ في 10 خطوات. الحل: الخطوة 1: $0.9^{10} \approx 0.349$. النتيجة: 35% فقط. الربط بالذكاء الاصطناعي: خطأ يتضخّم.

مثال (14-7.38): تقليل المعاملات المعطيات: $d_y = 10000$ كبير. المطلوب: حلّ. الحل: الخطوة 1: استخدام softmax مقسّم (sampled/candidate) أو طبقة projekt صغيرة. النتيجة: تقليل W_o. الربط بالذكاء الاصطناعي: تحسينات الخرج.

مثال (15-7.38): التحقّق من الاستقلال المعطيات: هل y_t مستقلّ عن y_{t-2} معرفة h'_t؟ المطلوب: اشرح. الحل: الخطوة 1: h'_t تحوي $h'_t, c \Rightarrow y_{<t}$. النتيجة: ماركوفيّة من الدرجة الأولى. الربط بالذكاء الاصطناعي: نموذج لغوي شرطيّ.

أخطاء شائعة

- **ظنّ السياق c يسع كلّ شيء:** عنق زجاجة يضعف مع الطول.
- **الخلط بين h_T المشفّر وh'_t فكّ التشفير:** مصفوفتان (أوزان) مختلفتان.
- **تجاهل bias: exposure** يضرب الأداء عند الاختبار.
- **نسيان رمز <EOS>:** التوليد لا يتوقّف.
- **افتراض أطوال متساوية:** المصدر والهدف حرّان.

صياغة رسمية: لتضمين مفردات حجمها V في فضاء بُعده d، مصفوفة التضمين $E \in \mathbb{R}^{V \times d}$ ولمدخل فهرس i نأخذ الصفّ

$$e_i = E[i, :] \tag{10.38}$$

وعدد معاملات التضمين $N_{\text{emb}} = V \cdot d$، وتعقيد خطوة RNN واحدة

$$C_{\text{step}} = O(d_h^2 + d_h d_x) \tag{11.38}$$

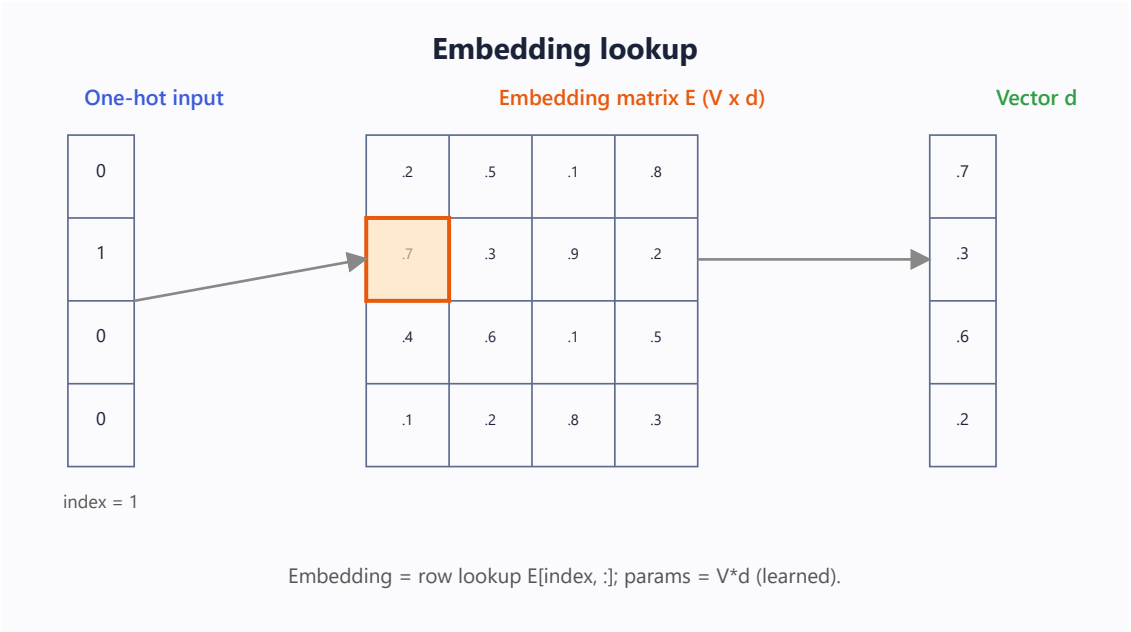
فإجمالي تدريب متسلسلة طولها T هو $O\big(T(d_h^2 + d_h d_x) + Vd\big)$.

جدول الرموز

الرمز	المعنى
V	حجم المفردات
d	بُعد التضمين
E	مصفوفة التضمين
e_i	متّجه الكلمة i

الرسم

<figure> الشكل<figcaption> 7.38: الفهرس ينتقي صفّاً من E ؛(lookup) لا توجد حسابات ضرب، فقط جدول.</figcaption> </figure>



شكل ٧.٣٨: *
التضمين

البرهان

الخطوة 1 (lookup لا ضرب): e_i صفّ من E يُسترجع مباشرةً $\Rightarrow O(d)$ لا $O(Vd)$. ■

الخطوة 2 (معاملات التضمين): E لها $V \cdot d$ مدخلات قابلة للتعلّم. ■

الخطوة 3 (تعقيد الخطوة): ضربا $W_h h$ و$W_x x$ هما المهيمنان $\Rightarrow$ (11.38). ■

خمسة عشر مثالاً محلولاً

مثال (1-8.38): معاملات تضمين المعطيات: $V = 10000, d = 300$. المطلوب: N_{emb}. الحل: الخطوة 1: $10000 \cdot 300 = 3 \times 10^6$. النتيجة: 3 مليون. الربط بالذكاء الاصطناعي: أكبر من RNN أحياناً.

مثال (2-8.38): مقارنة one-hot المعطيات: دخل one-hot بُعده V ثم طبقة كثيفة d $\rightarrow$ V. المطلوب: معاملات. الحل: الخطوة 1: $V \cdot d$ نفس (10.38) لكن lookup أسرع. النتيجة: متطابقة المعاملات. الربط بالذكاء الاصطناعي: lookup أوفر حساباً.

مثال (3-8.38): بُعد أكبر المعطيات: $V = 50000, d = 512$. المطلوب: N_{emb}. الحل: الخطوة 1: $50000 \cdot 512 = 2.56 \times 10^7$. النتيجة: 6.25 مليون. الربط بالذكاء الاصطناعي: نماذج لغوية كبيرة.

مثال (4-8.38): تعقيد الخطوة المعطيات: $d_h = 128, d_x = 300$ (بعد التضمين). المطلوب: C_{step}. الحل: الخطوة 1: $128^2 + 128 \cdot 300 = 16384 + 38400 = 54784$. النتيجة: ~55 ألف عملية/خطوة. الربط بالذكاء الاصطناعي: خطّي في T.

مثال (5-8.38): إجمالي التدريب المعطيات: $T = 50$ من (4-8.38)، $Vd = 3 \times 10^6$. المطلوب: التكلفة الكلّية. الحل: الخطوة 1: $50 \cdot 54784 = 2.74 \times 10^6$ (RNN) + 3×10^6 (emb) $\approx 5.74 \times 10^6$. النتيجة: ~7.5 مليون. الربط بالذكاء الاصطناعي: التضمين جزء كبير.

مثال (6-8.38): تقليل d المعطيات: $d = 50, V = 10000$. المطلوب: N_{emb}. الحل: الخطوة 1: $10000 \cdot 50 = 5 \times 10^5$. النتيجة: 5.0 مليون. الربط بالذكاء الاصطناعي: تضمين رخيص.

مثال (7-8.38): تضمين مشترك المعطيات: نشارك E بين المشفّر وفكّ التشفير. المطلوب: تأثير المعاملات. الحل:

الخطوة 1: نعدّ E مرّة لا اثنتين $\Rightarrow$ توفير Vd. النتيجة: أوفر. الربط بالذكاء الاصطناعي: embedding، shared.

مثال (8-8.38): lookup سرعة المعطيات: مقارنة $E[i,:]$ بضرب one-hot $E^\top x$. المطلوب: التكلفة. الحل: الخطوة 1: lookup $O(d)$، ضرب $O(Vd) \Rightarrow$ lookup أسرع V مرّات. النتيجة: فارق ضخم. الربط بالذكاء الاصطناعي: سبب استخدام lookup.

مثال (9-8.38): تجميد التضمين المعطيات: نثبّت E (pretrained). المطلوب: هل تُحسب معاملاته؟ الحل: الخطوة 1: لا تُحدَّث $\Rightarrow$ لا تدخل في التدرّج. النتيجة: مجّاني التدريب. الربط بالذكاء الاصطناعي: word2vec/GloVe.

مثال (10-8.38): بُعد الخرج المعطيات: $e_i \in \mathbb{R}^d$. المطلوب: يُغذّى إلى؟ الحل: الخطوة 1: يصبح $x_t = e_{i_t}$ بُعد d = d_x. النتيجة: $d_x = d$. الربط بالذكاء الاصطناعي: يطابق الدخل.

مثال (11-8.38): مفردات ضخمة المعطيات: $V = 10^6, d = 256$. المطلوب: N_{emb}. الحل: الخطوة 1: $10^6 \cdot 256 = 2.56 \times 10^8$. النتيجة: 256 مليون. الربط بالذكاء الاصطناعي: يتطلّب تقنيات (adaptive softmax).

مثال (12-8.38): تعقيد الذاكرة المعطيات: E تخزّن Vd أعداد. المطلوب: حجم $V = 50000, d = 512$ بدقّة 4 بايت. الحل: الخطوة 1: $2.56 \times 10^7 \cdot 4 = 1.024 \times 10^8$ بايت $\approx$ 102 ميغابايت. النتيجة: ~102 MB. الربط بالذكاء الاصطناعي: ذاكرة التضمين.

مثال (13-8.38): تسلسل أطول المعطيات: $T = 1000$ من (4-8.38). المطلوب: تكلفة RNN فقط. الحل: الخطوة 1: $54784 \cdot 1000 = 5.48 \times 10^7$. النتيجة: ~55 مليون. الربط بالذكاء الاصطناعي: التكلفة تخطيطيّاً $O(T)$.

مثال (14-8.38): مقارنة RNN مقابل LSTM كليّاً المعطيات: C_{step}، RNN=54784، LSTM×4≈219136. المطلوب: نسبة. الحل: الخطوة 1: $219136/54784 = 4$. النتيجة: LSTM 4× أبطأ. الربط بالذكاء الاصطناعي: ثمن البوّابات.

مثال (15-8.38): متى نستخدم تضميناً؟ المعطيات: ميزات عددية مستمرّة. المطلوب: هل نحتاج E؟ الحل: الخطوة 1: لا، التضمين للفئويّات/الرموز فقط. النتيجة: نتخطّاه. الربط بالذكاء الاصطناعي: ميزات قيمية مباشرة.

أخطاء شائعة

- **ظنّ lookup = ضرب مصفوفة:** هو استرجاع صفّ $O(d)$ لا $O(Vd)$.
- **حساب N_{emb} بـd_h بدل d:** التضمين بُعده d المستقل.
- **مشاركة التضمين تلقائيّاً:** يجب تفعيلها صراحةً.
- **إهمال أن التضمين قد يهيمن على المعاملات:** خاصّة بـV كبيرة.
- **تجميد التضمين دون تعديل d_x:** يجب مطابقة الأبعاد.

جدول تجميعي لنظريات الفصل

النظرية	العنوان	الصيغة المحوريّة
2.38	الخلية المتكرّرة	$h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$
3.38	BPTT	$\partial h_t/\partial h_k = \prod \operatorname{diag}(1-h^2) W_h$
4.38	التلاشي/الانفجار	$\|\partial h_t/\partial h_1\| \approx \rho(W_h)^{t-1}$
5.38	LSTM	$C_t = f_t \odot C_{t-1} + i_t \odot g_t$
6.38	GRU	$h_t = (1-z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$
7.38	Seq2Seq	$h'_t = \tanh(W_h h'_{t-1} + W_y y_{t-1} + Uc)$
8.38	التضمين	$e_i = E[i,:],\ N_{\text{emb}} = Vd$

عشرون تمريناً مع الإجابات

١. **(تمرين)** $d_h = 64, d_x = 32, d_y = 10$ احسب N_{RNN}. **إجابة:** $64^2 + 64 \cdot 32 + 64 + 10 \cdot 64 + 10 = 4096 + 2048 + 64 + 640 + 10 = 6862$.

٢. **(تمرين)** أثبت أن BPTT يعطي جداء يعقوبيّات. **إجابة:** من قاعدة السلسلة وتعريف h_t.

٣. **(تمرين)** $\rho = 0.9, t = 5$ احسب معامل التلاشي. **إجابة:** $0.9^4 = 0.656$.

٤. **(تمرين)** $\rho = 1.2, t = 10$ احسب معامل الانفجار. **إجابة:** $1.2^9 \approx 5.16$.

٥. **(تمرين)** LSTM $d_h = 64, d_x = 32$ احسب N. **إجابة:** $4(64{\cdot}96{+}64) = 4(6144{+}64) = 4{\cdot}6208 = 24832$.

٦. **(تمرين)** GRU نفس الأبعاد احسب N. **إجابة:** $3(64 \cdot 96 + 64) = 3 \cdot 6208 = 18624$.

٧. **(تمرين)** نسبة LSTM/GRU. **إجابة:** $24832/18624 = 1.33$.

٨. **(تمرين)** $f_t = 1, i_t = 0$ احسب C_t. **إجابة:** $C_t = C_{t-1}$.

٩. **(تمرين)** $z_t = 0.5, h_{t-1} = [1, 1], \tilde{h} = [3, 3]$ احسب h_t (GRU). **إجابة:** $0.5[1, 1] + 0.5[3, 3] = [2, 2]$.

١٠. **(تمرين)** $V = 20000, d = 100$ احسب N_{emb}. **إجابة:** 2×10^6.

١١. **(تمرين)** لماذا يفشل السياق الثابت مع جمل طويلة؟ **إجابة:** عنق زجاجة بُعده ثابت.

١٢. **(تمرين)** ماذا يسبّب forcing teacher؟ **إجابة:** bias exposure عند الاختبار.

١٣. **(تمرين)** $d_h = 128, d_x = 300, T = 40$ احسب تكلفة RNN تقريباً. **إجابة:** $40 \cdot (128^2 + 128 \cdot 300) = 40 \cdot (16384 + 38400) = 40 \cdot 54784 = 2.19 \times 10^6$.

١٤. **(تمرين)** متى $\partial C_t / \partial C_{t-1} \approx 1$؟ **إجابة:** عند $f_t \approx 1$.

١٥. **(تمرين)** كم بوّابة في GRU؟ **إجابة:** 2 (r,z).

١٦. **(تمرين)** كم تحويل في LSTM؟ **إجابة:** 4.

١٧. **(تمرين)** clipping تدرّج بقيمة 50. **إجابة:** يُقصر إلى 50.

١٨. **(تمرين)** lookup embedding مقابل ضرب one-hot: التكلفة. **إجابة:** $O(d)$ مقابل $O(Vd)$.

١٩. **(تمرين)** $h_t = \tanh(2h_{t-1})$، هل يستقرّ؟ **إجابة:** لا، $\rho = 2 > 1 \Rightarrow$ انفجار.

٢٠. **(تمرين)** لماذا GRU شائع عمليّاً؟ **إجابة:** أبسط وأخفّ من LSTM بأداء قريب.

فهرس الرموز

- x_t, h_t, y_t — دخل/حالة/خرج اللحظة t.
- W_h, W_x, W_y — أوزان الخلية.
- C_t, f_t, i_t, o_t — حالة الخلية وبوّابات LSTM.
- $r_t, z_t, \tilde{h}_t$ — بوّابات وإسقاط GRU.
- c — ناقل السياق في seq2seq.
- E, e_i — مصفوفة التضمين ومتّجه الكلمة.
- ρ — نصف القطر الطيفي.

المراجع

- J. Elman, *Finding Structure in Time* (RNN مبكّر).
- J. Schmidhuber, S., Hochreiter, *Long Short-Term Memory*.
- K. Cho, et al. *Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation* (GRU).
- I. Sutskever, et al. *Sequence to Sequence Learning with Neural Networks*.
- S. Bengio, et al. *Scheduled Sampling* (حلّ exposure bias).
- A. Courville, Y., Bengio, I., Goodfellow, *Deep Learning* (فصل التسلسلات).
- T. Mikolov, et al. *Efficient Estimation of Word Representations* (word2vec).

<!-- نهاية الفصل الثامن والثلاثون -->

المحوّلات: الانتباه، الترميز الموضعيّ، والتعقيد

«المحوّل لا يقرأ الكلمةَ تلو الأخرى، بل يُلقي نظرةً واحدةً على الجميع، فلا زمنَ يعيقه.»

بعد أن عانينا من تلاشي الزمن في RNN، نتساءل: هل نستغني عن التتابع تماماً؟ المحوّل (Transformer) يجيب بحوسبة الانتباه المتوازية: كلّ رمز ينظر إلى كلّ الرموز دفعةً واحدة. هذا الفصل يُثبِتُ الانتباه المُقاس، تعدّد الرؤوس، الترميز الموضعيّ، كتلة المحوّل، التعقيد والقناع، الانتباه المتقاطع، وبدائل الانتباه الفعّالة.
سبع نظريات:

- **2.39 الانتباه المُقاس بمُنتج النقاط** — $\text{Attn}(Q,K,V)=\text{softmax}(QK^\top/\sqrt{d_k})V$.
- **3.39 تعدّد الرؤوس (Multi-Head)** — $h_i=\text{Attn}(QW_i^Q,KW_i^K,VW_i^V)$ ثمّ دمج.
- **4.39 الترميز الموضعيّ الجيبيّ** — $PE_{pos,2i}=\sin(pos/10000^{2i/d})$.
- **5.39 كتلة المحوّل (FFN + المتبقّي + LayerNorm)** — $\text{FFN}(x)=\max(0,xW_1+b_1)W_2+b_2$.
- **6.39 التعقيد والقناع (masking)** — $O(n^2d)$، قناع سببيّ/حشو.
- **7.39 الانتباه المتقاطع والتوليد التلقائيّ** — Q من فكّ التشفير وK,V من المشفّر.
- **8.39 الانتباه الفعّال (Sparse/Linformer/Performer)** — خفض n^2 إلى n أو $\log n$.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
Q,K,V	الاستعلام، المفتاح، القيمة	مصفوفات $n\times d$
n	طول المتسلسلة	عدد الرموز
d_k,d_v	أبعاد المفتاح/القيمة	غالباً d_{model}/h
h	عدد الرؤوس	heads
d_{model}	بُعد النموذج	بُعد مُوحّد
PE	الترميز الموضعيّ	يُضاف للتضمين

الاتفاقيات: كلّ المتجهات في صفّ؛ softmax LTR يُطبَّق صفّاً صفّاً على آخر بُعد.

صياغة رسمية: لِـ $Q\in\mathbb{R}^{n\times d_k}$، $K\in\mathbb{R}^{m\times d_k}$، $V\in\mathbb{R}^{m\times d_v}$،

$$\text{Attention}(Q,K,V)=\text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V \tag{1.39}$$

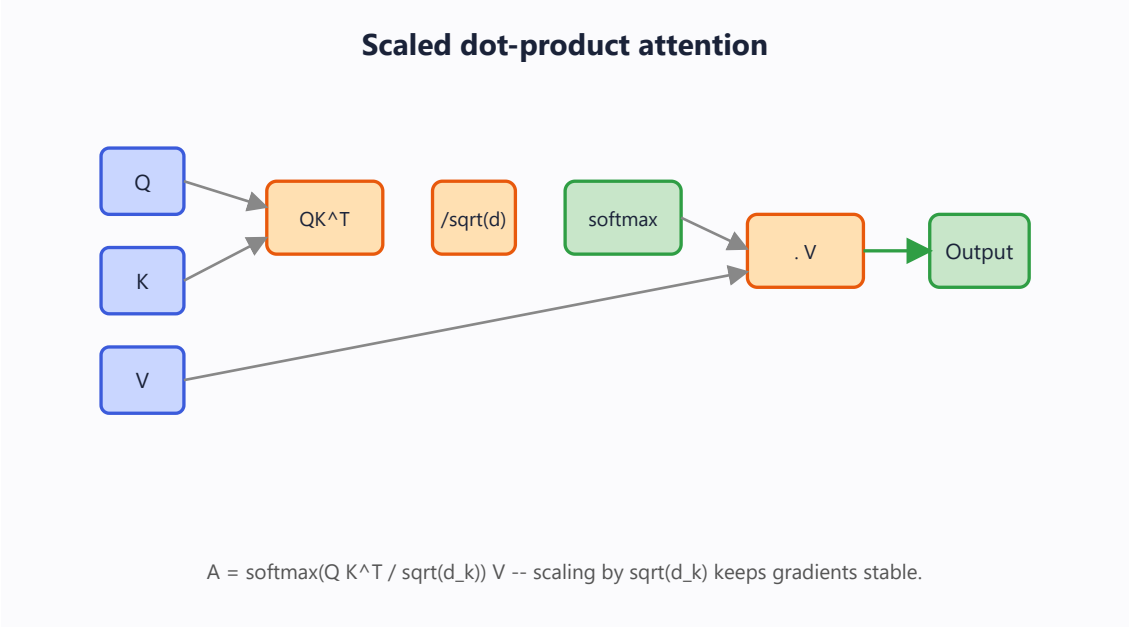
حيث softmax على كلِّ صفّ. الناتج بأبعاد $n\times d_v$.

جدول الرموز

الرمز	المعنى
$QK^\top$	درجات التشابه (نقاط)
$\sqrt{d_k}$	معامل التقريب (scaling)
$\mathrm{softmax}(\cdot)V$	تجميع القيم بأوزان الانتباه

الرسم

<figure> الشكل<figcaption> 1.39: من Q, K, V إلى درجات $QK^\top$، تقريب، softmax، ثمّ ضرب في



شكل ١.٣٩: *
الانتباه المقاس

</figure> .</figcaption>V

البرهان

الخطوة 1 (درجات التشابه): $(QK^\top)_{ij} = \langle q_i, k_j \rangle$ يقيس مدى ارتباط الاستعلام i بالمفتاح j. ■

الخطوة 2 (التقريب): لـ d_k كبيرة، تتباعد منتجات النقاط $\Rightarrow$ تقريب بـ $\sqrt{d_k}$ يُبقي تباين softmax معتدلاً (يمنع تشبّعاً نحو one-hot). ■

الخطوة 3 (التجميع): أوزان الانتباه $A = \mathrm{softmax}(QK^\top/\sqrt{d_k})$؛ AV يجمع القيم بحسب الأهمية. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.39): أبعاد متوافقة المعطيات: $Q \in \mathbb{R}^{3\times 4}, K \in \mathbb{R}^{5\times 4}, V \in \mathbb{R}^{5\times 6}$. المطلوب: أبعاد الناتج. الحل: الخطوة 1: $QK^\top \in \mathbb{R}^{3\times 5}$؛ softmax $\Rightarrow 3\times 5$؛ $\times V(5\times 6) \Rightarrow 3\times 6$. النتيجة: 3×6. الربط بالذكاء الاصطناعي: عدد الاستعلامات يحدّد طول الخرج.

مثال (2-2.39): درجة واحدة المعطيات: $q = [1,0,0,0]^\top, k = [1,0,0,0]^\top$. المطلوب: النقطة قبل التقريب. الحل: الخطوة 1: $\langle q, k \rangle = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: تطابق تامّ يعطي درجة عالية.

مثال (39.2-3): تقريب بـ$\sqrt{d_k}$ المعطيات: $d_k = 64$، نقطة $= 8$. المطلوب: القيمة المُقاسَة. الحل: الخطوة 1: $\sqrt{64} = 8$؛ $8/8 = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: بدون تقريب كانت 8 (كبيرة).

مثال (39.2-4): softmax صفّ واحد المعطيات: $[2, 1, 0]$ قبل softmax. المطلوب: الأوزان. الحل: الخطوة 1: $e^2 + e^1 + e^0 = 7.389 + 2.718 + 1 = 11.107$؛ الأوزان $[0.665, 0.245, 0.090]$. النتيجة: $[0.665, 0.245, 0.090]$. الربط بالذكاء الاصطناعي: الأول يهيمن.

مثال (39.2-5): تجميع القيم المعطيات: أوزان $[0.665, 0.245, 0.090]$، $V = [[1, 0], [0, 1], [1, 1]]$. المطلوب: الناتج. الحل: الخطوة 1: $0.665[1, 0] + 0.245[0, 1] + 0.090[1, 1] = [0.755, 0.335]$. النتيجة: $[0.755, 0.335]$. الربط بالذكاء الاصطناعي: متوسط مرجّح بالانتباه.

مثال (39.2-6): لماذا التقريب ضروريّ؟ المعطيات: $d_k = 1000$، نقاط $\sim \mathcal{N}(0, 1000)$. المطلوب: ماذا يحدث بلا تقريب؟ الحل: الخطوة 1: قيم كبيرة جدًّا $\Rightarrow$ softmax يصبح one-hot قاسٍ $\Rightarrow$ تدرّجات صفرية. النتيجة: تشبّع. الربط بالذكاء الاصطناعي: التقريب يُخفّفه.

مثال (39.2-7): $Q = K = V$ (sefl-attention) المعطيات: $X \in \mathbb{R}^{n \times d}$، $Q = K = V = X$. المطلوب: ماذا يعني؟ الحل: الخطوة 1: كلّ رمز ينتبه لكلّ الرموز بما فيها نفسه. النتيجة: سياق كليّ. الربط بالذكاء الاصطناعي: أساس المحوّل.

مثال (39.2-8): تعقيد الضرب المعطيات: $n = 100, d = 512$. المطلوب: عمليّات $QK^\top$. الحل: الخطوة 1: $n \cdot n \cdot d = 100 \cdot 100 \cdot 512 = 5.12 \times 10^6$. النتيجة: ~1.5 مليون. الربط بالذكاء الاصطناعي: $O(n^2 d)$.

مثال (39.2-9): انتباه ثنائي الأبعاد المعطيات: $d_k = 1, q = [2], K = [[1], [3]]$. المطلوب: الدرجات. الحل: الخطوة 1: $[2 \cdot 1, 2 \cdot 3] = [2, 6]$ (بلا تقريب لـ$d_k = 1$). النتيجة: $[2, 6]$. الربط بالذكاء الاصطناعي: تشابه خطّيّ.

مثال (39.2-10): إضافة القناع المعطيات: درجات $[2, 6]$، نقنّع الثاني (∞). المطلوب: أوزان softmax. الحل: الخطوة 1: $[2, -\infty] \Rightarrow [e^2, 0]/e^2 = [1, 0]$. النتيجة: $[1, 0]$. الربط بالذكاء الاصطناعي: القناع يمنع الانتباه.

مثال (39.2-11): تطبيع الصفوف المعطيات: هل مجموع أوزان الصفّ = 1؟ المطلوب: تحقّق. الحل: الخطوة 1: softmax معرّف ليجمع 1 على كلّ صفّ. النتيجة: نعم. الربط بالذكاء الاصطناعي: أوزان احتمالية.

مثال (39.2-12): $d_k \neq d_v$ المعطيات: $d_k = 64, d_v = 128$. المطلوب: هل يؤثّر على (39.1)؟ الحل: الخطوة 1: التقريب بـ$\sqrt{d_k}$؛ V بُعده $d_v \Rightarrow$ الناتج $d_v = 128$. النتيجة: الناتج 128. الربط بالذكاء الاصطناعي: القيمة قد تتوسّع.

مثال (39.2-13): انتباه متعدّد الاستعلامات المعطيات: $n = 10$ استعلام. المطلوب: كم خرج؟ الحل: الخطوة 1: كلّ استعلام يعطي متّجهًا $\Rightarrow$ 10 متّجهات. النتيجة: 10. الربط بالذكاء الاصطناعي: طول الخرج = عدد الاستعلامات.

مثال (39.2-14): حساب ذاكرة الخريطة المعطيات: $n = 512$ توتر انتباه. المطلوب: عناصر A. الحل: الخطوة 1: $512 \times 512 = 262144$. النتيجة: ~262 ألف. الربط بالذكاء الاصطناعي: n^2 تنفخ الذاكرة.

مثال (39.2-15): التدرّج عبر softmax المعطيات: $\partial L/\partial A$ معلوم. المطلوب: أين يبدأ الانتشار؟ الحل: الخطوة 1: ∂A يمرّ عبر $QK^\top/\sqrt{d_k}$ ثمّ إلى Q, K, V. النتيجة: تدرّج كامل. الربط بالذكاء الاصطناعي: backprop عبر الانتباه مُحتَمد.

أخطاء شائعة

- **نسيان تقريب $\sqrt{d_k}$:** تشبّع softmax وتلاشي التدرّج.
- **خلط $QK^\top$ مع $Q^\top K$:** الأبعاد تختلف.
- **ظنّ softmax على المصفوفة كلّها:** يُطبَّق صفّاً صفّاً.

- **إهمال القناع:** الانتباه يرى المستقبل/الحشو.
- **الخلط بين d_k وd_v:** التقريب بـd_k لا d_v.

صياغة رسمية: مع رؤوس h، لكلّ رأس i إسقاطات $W_i^Q \in \mathbb{R}^{d_{model}\times d_k}$، $W_i^K \in \mathbb{R}^{d_{model}\times d_k}$، $W_i^V \in \mathbb{R}^{d_{model}\times d_v}$، نحسب

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \tag{2.39}$$

ثمّ نُدمج: $\text{MultiHead}(Q,K,V) = \text{Concat}(\text{head}_1,\dots,\text{head}_h)W^O$، وعدد المعاملات الإسقاطيّة (مع $d_k = d_v = d_{model}/h$) $W^O \in \mathbb{R}^{hd_v\times d_{model}}$.

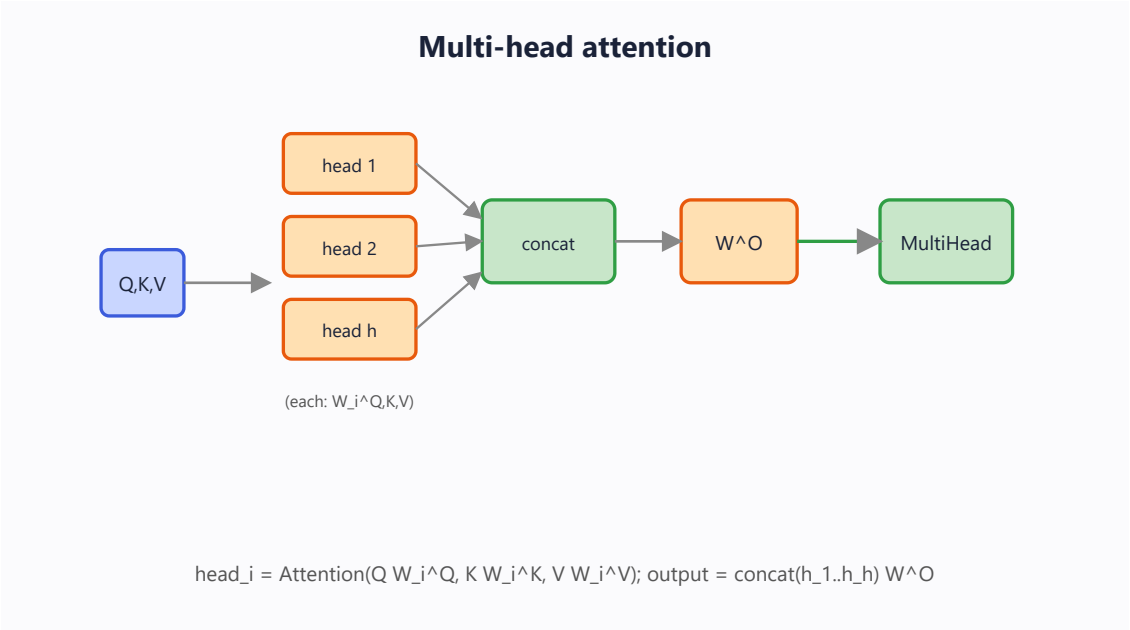
$$N_{\text{MHA}} = 4\,d_{model}^2 \tag{3.39}$$

جدول الرموز

الرمز	المعنى
h	عدد الرؤوس
d_k, d_v	بُعد الرأس ($= d_{model}/h$)
W^O	إسقاط الدمج

الرسم

<figure> الشكل<figcaption> 2.39: كلّ رأس ينتبه بإسقاطاته الخاصة؛ الدمج بـW^O يعيد البُعد d_{model}.</figcaption>



شكل ٢.٣٩: *
تعدد الرؤوس

</figure>

البرهان

الخطوة 1 (كلفة الرأس): ثلاثة إسقاطات $d_{model} \times d_k$ لكلّ رأس $\Rightarrow 3hd_{model}d_k = 3d_{model}^2$ لأن $hd_k = d_{model}$. ■

الخطوة 2 (دمج): W^O أبعادها $hd_v \times d_{model} = d_{model} \times d_{model}$ إضافية. ■

الخطوة 3 (الجمع): $3d_{model}^2 + d_{model}^2 = 4d_{model}^2$ $\Rightarrow$ (3.39). ■

خمسة عشر مثالاً محلولاً

مثال (3.39-1): معاملات المحوّل القياسيّ المعطيات: $d_{model} = 512, h = 8$. المطلوب: N_{MHA}. الحل: الخطوة 1: $4 \cdot 512^2 = 4 \cdot 262144 = 1048576$. النتيجة: 1,048,576. الربط بالذكاء الاصطناعي: وحدة الانتباه في base Transformer.

مثال (3.39-2): بُعد الرأس المعطيات: $d_{model} = 512, h = 8$. المطلوب: d_k. الحل: الخطوة 1: $d_k = 512/8 = 64$. النتيجة: 64. الربط بالذكاء الاصطناعي: كلّ رأس منخفض البُعد.

مثال (3.39-3): عدد الرؤوس أكبر المعطيات: $d_{model} = 512, h = 16$. المطلوب: d_k وN. الحل: الخطوة 1: $d_k = 32$، $N = 4 \cdot 512^2 = 1048576$ (ثابتة!). النتيجة: $d_k = 32, N$ ثابتة. الربط بالذكاء الاصطناعي: h لا يغيّر المعاملات.

مثال (3.39-4): بُعد الدمج المعطيات: $h = 8, d_v = 64$. المطلوب: أبعاد W^O. الحل: الخطوة 1: $hd_v = 512$ صفوفاً، $d_{model} = 512$ أعمدة $\Rightarrow 512 \times 512$. النتيجة: 512×512. الربط بالذكاء الاصطناعي: يعيد البُعد الكلّيّ.

مثال (3.39-5): أبعاد الخرج الكليّ المعطيات: $Q \in \mathbb{R}^{n \times 512}$. المطلوب: بُعد MultiHead. الحل: الخطوة 1: كلّ رأس $n \times 64$، دمج $\Rightarrow n \times 512$. النتيجة: $n \times 512$. الربط بالذكاء الاصطناعي: يحفظ البُعد.

مثال (3.39-6): رأس واحد كحالة خاصّة المعطيات: $h = 1$. المطلوب: هل يساوي (1.39)؟ الحل: الخطوة 1: Concat = الرأس نفسه، W^O إسقاط $d_{model} \to d_v$ $\Rightarrow$ تعميم. النتيجة: نعم (مع إسقاط إضافيّ). الربط بالذكاء الاصطناعي: MHA تُعمّم الانتباه.

مثال (3.39-7): معاملات كلّ رأس وحده المعطيات: $d_{model} = 512, d_k = 64$. المطلوب: N للرأس الواحد (بلا W^O). الحل: الخطوة 1: $3 \cdot 512 \cdot 64 = 98304$. النتيجة: 98304 للرأس. الربط بالذكاء الاصطناعي: تتكرّر h مرّة.

مثال (3.39-8): مقارنة مع attention واحد بـd_{model} المعطيات: بديل: انتباه واحد بـ$d_k = d_{model}$. المطلوب: N؟ الحل: الخطوة 1: $3d_{model}^2 + d_{model}^2 = 1048576$ أيضاً (نفس العدد تقريباً). النتيجة: متقاربة. الربط بالذكاء الاصطناعي: الفائدة في التعبير لا العدد.

مثال (3.39-9): لماذا heads مفيد؟ المعطيات: كلّ رأس يتعلّم علاقة مختلفة. المطلوب: اشرح رياضيّاً. الحل: الخطوة 1: الإسقاطات W_i مختلفة $\Rightarrow$ فضاءات فرعية مستقلة $\Rightarrow$ تمثيل متعدّد الجوانب. النتيجة: تمثيل أغنى. الربط بالذكاء الاصطناعي: مثل قنوات الالتفاف.

مثال (3.39-10): تعقيد الحساب المعطيات: $n = 100, d_{model} = 512, h = 8$. المطلوب: عمليّات MHA. الحل: الخطوة 1: الإسقاطات $O(nd_{model}^2)$ + الانتباه $h \cdot O(n^2 d_k)$، الطاغي $O(n^2 d_{model})$. النتيجة: ~خطّي في d، تربيعيّ في n. الربط بالذكاء الاصطناعي: عنق الزجاجة الزمنيّ.

مثال (3.39-11): h غير منقسم بالتساوي المعطيات: $d_{model} = 512, h = 7$. المطلوب: d_k؟ الحل: الخطوة 1: عادةً $d_k = \lfloor 512/7 \rfloor = 73$ (مع حشو) أو تعديل d_{model}. النتيجة: ~73. الربط بالذكاء الاصطناعي: الأفضل d_{model} يقبل القسمة.

مثال (3.39-12): الذاكرة للرؤوس المعطيات: خريطة انتباه $n = 100, h = 8$. المطلوب: عناصر. الحل: الخطوة 1: $8 \cdot 100 \cdot 100 = 80000$. النتيجة: 80 ألف. الربط بالذكاء الاصطناعي: h يضاعف الذاكرة.

مثال (13-3.39): دمج بلا W^O المعطيات: لو أهملنا W^O؟ المطلوب: التبعة. الحل: الخطوة 1: الأبعاد تبقى hd_v لا d_{model} ⇒ لا تطابق الطبقة التالية. النتيجة: خطأ بُعد. الربط بالذكاء الاصطناعي: W^O ضروريّ.

مثال (14-3.39): تكلفة التدرّج المعطيات: ∂W^O أبعاده؟ الحل: الخطوة 1: مثل W^O: $d_{model} \times d_{model}$ 512×512. النتيجة: 262144 معاملاً في التدرّج. الربط بالذكاء الاصطناعي: backprop يطابق الأمام.

مثال (15-3.39): نموّ مع d_{model} المعطيات: $d_{model} = 256$ مقابل 512. المطلوب: نسبة N. الحل: الخطوة 1: $4 \cdot 256^2 = 262144$ مقابل $1048576 \Rightarrow 1/4$. النتيجة: الربع. الربط بالذكاء الاصطناعي: مربّع في d_{model}.

أخطاء شائعة

- **نسيان W^O:** الدمج غير مكتمل.
- **خلط d_k مع d_{model}:** $d_k = d_{model}/h$ لا d_{model}.
- **ظنّ زيادة h تزيد المعاملات:** ثابتة (مع $d_k = d_{model}/h$).
- **إهمال أن كلّ رأس مستقلّ:** يُعلّم علاقات مختلفة.
- **الخلط بين MultiHead وعدّة انتباهات متسلسلة:** هي متوازية.

صياغة رسمية: لِلموضع pos والبُعد $i \in \{0, \dots, d_{model}/2 - 1\}$،

$$PE_{(pos,2i)} = \sin\Big(\frac{pos}{10000^{2i/d_{model}}}\Big), \qquad PE_{(pos,2i+1)} = \cos\Big(\frac{pos}{10000^{2i/d_{model}}}\Big) \tag{4.39}$$

ثمّ نُضيف الترميز للتضمين: $x_{pos} = e_{token} + PE_{pos}$.

جدول الرموز

الرمز	المعنى
pos	رقم الموضع (0,1,2,...)
i	مؤشّر البُعد
10000	أساس التردّد

الرسم

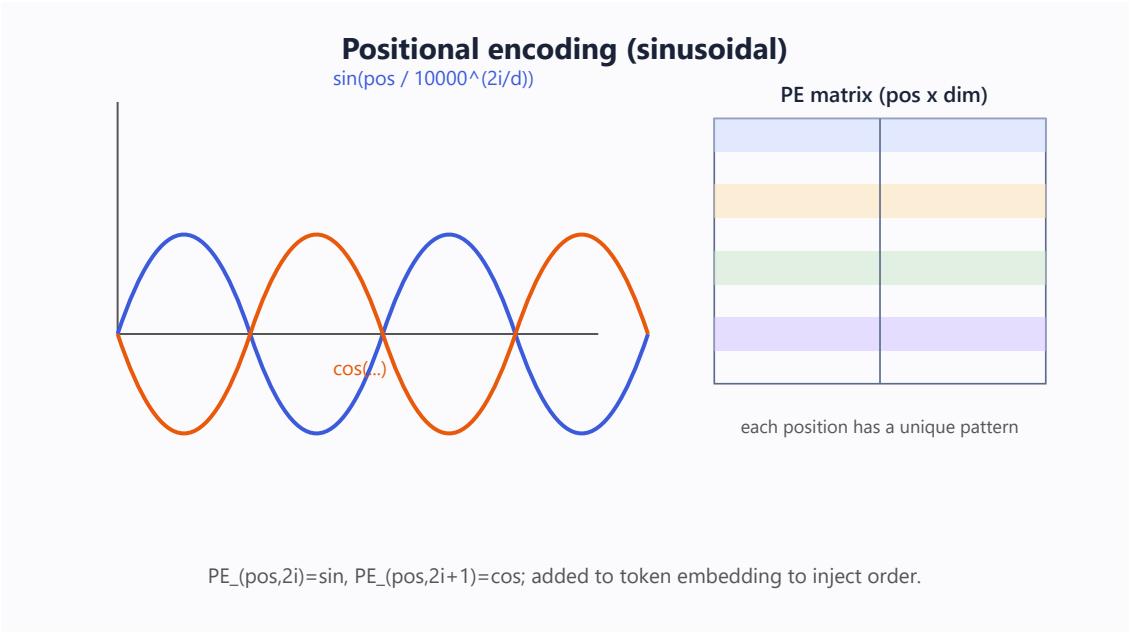
<figure> الشكل<figcaption> 3.39: منحنيات الجيب/جيب التمام بتردّدات متناقصة عبر الأبعاد، كلّ موضع نمط فريد.</figcaption> </figure>

البرهان

الخطوة 1 (الدوريّة): sin / cos دوريّة ⇒ تمثيل موضع محدود النطاق لكن بأبعاد تردّد متفاوتة. ■

الخطوة 2 (الترجمة الخطّية): بفضل صيغ الجمع، PE_{pos+k} هي تحويل خطّيّ لـPE_{pos} ⇒ النموذج يتعلّم العلاقات الموضعيّة النسبية بسهولة. ■

الخطوة 3 (الإضافة): إضافة PE للتضمين تحفظ بُعد d_{model} وتُحقن الترتيب دون معاملات إضافية. ■



شكل ٣٠٣٩: *
الترميز الموضعي

خمسة عشر مثالاً محلولاً

مثال (1-4.39): قيمة عند i=0 المعطيات: $pos = 1, d_{model} = 512, i = 0$. المطلوب: $PE_{(1,0)}$. الحل: الخطوة 1: $10000^0 = 1$، $\sin(1/1) = \sin(1) \approx 0.841$. النتيجة: 0.841. الربط بالذكاء الاصطناعي: البُعد الأول تردّد أعلى.

مثال (2-4.39): بعد كبير i المعطيات: $pos = 100, i = 255, d_{model} = 512$. المطلوب: التردّد. الحل: الخطوة 1: $10000^{2 \cdot 255/512} = 10000^{0.996} \approx 10^{3.98} \approx 9550$، الحجّة $100/9550 \approx 0.0105 \Rightarrow \sin \approx 0.0105$. النتيجة: ~0.0105 (بطيء التغيّر). الربط بالذكاء الاصطناعي: الأبعاد العليا تردّد منخفض.

مثال (3-4.39): الموضع 0 المعطيات: $pos = 0$. المطلوب: $PE_{(0,\cdot)}$. الحل: الخطوة 1: $\sin(0) = 0$ لكلّ $2i$، $\cos(0) = 1$ لكلّ $2i + 1 \Rightarrow$ نمط $[0, 1, 0, 1, \ldots]$. النتيجة: بديل ثابت. الربط بالذكاء الاصطناعي: الموضع الأول متميّز.

مثال (4-4.39): الدوريّة المعطيات: هل PE تتكرّر؟ المطلوب: اشرح. الحل: الخطوة 1: sin / cos دوريّة لكنّ بُعداً واحداً فقط؛ التوليفة الكلّية فريدة عمليّاً. النتيجة: لا تكرار ملحوظ. الربط بالذكاء الاصطناعي: تفريد المواضع.

مثال (5-4.39): إضافة للتضمين المعطيات: $e = [0.2, 0.5]$، $PE = [0.84, 0.54]$. المطلوب: x_{pos}. الحل: الخطوة 1: $[0.2 + 0.84, 0.5 + 0.54] = [1.04, 1.04]$. النتيجة: $[1.04, 1.04]$. الربط بالذكاء الاصطناعي: حقن الترتيب.

مثال (6-4.39): علاقة pos و pos+k المعطيات: $k = 1$. المطلوب: هل يمكن استنتاج PE_{pos+1} من PE_{pos}؟ الحل: الخطوة 1: نعم عبر مصفوفة دوران R لأن $\sin(a+1), \cos(a+1)$ دوالّ خطّية في $\sin a, \cos a$. النتيجة: تحويل خطّيّ. الربط بالذكاء الاصطناعي: النموذج يتعلّم الإزاحة.

مثال (7-4.39): عدد المعاملات المعطيات: هل PE مُعلَّمة؟ المطلوب: N لـPE. الحل: الخطوة 1: PE محسوبة دون تعلّم $\Rightarrow 0$ معامل. النتيجة: مجّاني. الربط بالذكاء الاصطناعي: لا تكلفة.

مثال (8-4.39): الترميز القابل للتعلّم المعطيات: بديل: PE مُعلَّمة بُعدها d $\times$ n_{max}. المطلوب: N لـ$n_{max} = 5000, d = 512$. الحل: الخطوة 1: $5000 \cdot 512 = 2.56 \times 10^6$. النتيجة: 56.2 مليون (مكلف). الربط

بالذكاء الاصطناعي: الجيبيّ أوفر.

مثال (9-4.39): نسبة الإشارة المعطيات: تضمين بتباين 1، PE سعة ~1. المطلوب: توازن؟ الحل: الخطوة 1: كلاهما نفس الرتبة ⇒ يؤثّران بالتساوي. النتيجة: متوازن. الربط بالذكاء الاصطناعي: أحياناً نضرب PE بمعامل.

مثال (10-4.39): تماثل الترجمة المعطيات: $PE_{pos+k} = R^k PE_{pos}$. المطلوب: فائدة؟ الحل: الخطوة 1: علاقة موضع نسبية خطّية ⇒ الانتباه يلتقط "بعد k". النتيجة: تعميم أفضل. الربط بالذكاء الاصطناعي: أهمّية العلاقة النسبية.

مثال (11-4.39): أساس مختلف المعطيات: لو 1000 بدل 10000؟ المطلوب: التأثير. الحل: الخطوة 1: تردّدات أعلى ⇒ دوريّة أسرع ⇒ تشابك المواضع البعيدة. النتيجة: أضعف تمييزاً. الربط بالذكاء الاصطناعي: 10000 مُختارة تجريبيّاً.

مثال (12-4.39): بُعد فرديّ/زوجيّ المعطيات: $d_{model} = 4$. المطلوب: صيغ الأبعاد. الحل: الخطوة 1: $i = 0$: $\sin(pos/10000^0), \cos(\dots)$؛ $i = 1$: $\sin(pos/10000^{2/4}), \cos(\dots)$. النتيجة: 4 قيم. الربط بالذكاء الاصطناعي: زوجيّ sin، فرديّ cos.

مثال (13-4.39): موضع كبير جدّاً المعطيات: $pos = 10000$. المطلوب: هل تنفجر القيم؟ الحل: الخطوة 1: $\sin / \cos \in [-1, 1]$ دائماً ⇒ محصورة. النتيجة: مستقرّة. الربط بالذكاء الاصطناعي: لا انفجار.

مثال (14-4.39): تطبيق على متّجه المعطيات: $d_{model} = 512$، نريد PE للموضع 5. المطلوب: بُعد المتّجه. الحل: الخطوة 1: 512 قيمة (نصف sin نصف cos). النتيجة: 512. الربط بالذكاء الاصطناعي: يطابق التضمين.

مثال (15-4.39): لماذا لا RNN؟ المعطيات: المحوّل بلا RNN. المطلوب: كيف يعرف الترتيب؟ الحل: الخطوة 1: PE تُضخ الترتيب صراحةً ⇒ لا حاجة لتسلسل زمنيّ. النتيجة: موازاة كاملة. الربط بالذكاء الاصطناعي: سرعة التدريب.

أخطاء شائعة

- **ظنّ PE تُعلَّم دائماً:** الجيبيّة ثابتة ومجّانية.
- **نسيان الإضافة لا التسلسل:** $x = e + PE$ لا $[e; PE]$.
- **خلط $2i$ و$2i+1$:** sin للزوجيّ، cos للفرديّ.
- **اعتبار PE فريدة تماماً:** قد تتشابه عند أبعاد منخفضة التردّد.
- **إهمال أن التردّدات متناقصة:** ذلك يرمّز المقاييس المختلفة.

صياغة رسمية: بعد الانتباه، تمرّ الكتلة بطبقة تغذية أمامية ومتبقّيات وتطبيع:

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2, \qquad W_1 \in \mathbb{R}^{d_{model} \times d_{ff}},\ W_2 \in \mathbb{R}^{d_{ff} \times d_{model}} \tag{5.39}$$

وتُطبَّق بهيكلية: $x' = \mathrm{LayerNorm}(x + \mathrm{Sublayer}(x))$ (المتبقّي + التطبيع). عادةً $d_{ff} = 4d_{model}$، فمعاملات الـFFN الواحدة

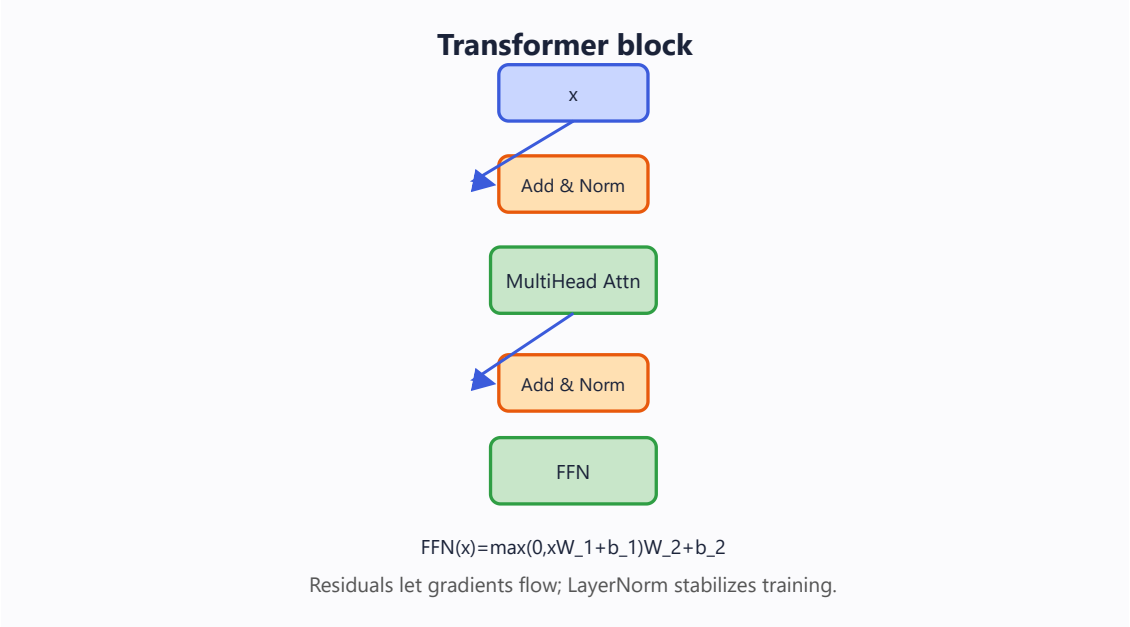
$$N_{\mathrm{FFN}} = 2\, d_{model}\, d_{ff} + d_{ff} + d_{model} = 8d_{model}^2 + 5d_{model} \tag{6.39}$$

جدول الرموز

الرمز	المعنى
d_{ff}	بُعد الطبقة الداخلية (مخفيّ)
Sublayer	الانتباه أو FFN
LayerNorm	تطبيع لكلّ عيّنة

الرسم

<figure> الشكل<figcaption> 4.39: اتصال متبقّي حول الانتباه وFFN، مع Add&Norm بعد كلّ



شكل ٤.٣٩: *
كتلة المحوّل

منهما.</figcaption> </figure>

البرهان

الخطوة 1 (معاملات FFN): W_1 لها $d_{ff}d_{model}$، W_2 لها $d_{model}d_{ff}$، الانحيازات $d_{ff}+d_{model}$. $\Rightarrow$ (6.39). ■

الخطوة 2 (المتبقّي): $x + \text{Sublayer}(x)$ يبقي أبعاد d_{model} ويُمرّر التدرّج مباشرةً عبر المسار المُختصَر. ■

الخطوة 3 (LayerNorm): $\text{LayerNorm}(u) = \gamma \odot (u-\mu)/\sqrt{\sigma^2+\epsilon} + \beta$ يُثبّت المتوسّط/التباين لكلّ عيّنة $\Rightarrow$ تدريب أسرع وأكثر استقراراً. ■

خمسة عشر مثالاً محلولاً

مثال (5.39-1): معاملات FFN (base) المعطيات: $d_{model} = 512, d_{ff} = 2048$. المطلوب: N_{FFN}. الحل: الخطوة 1: $2099712 = 2097152 + 2560 = 2 \cdot 512 \cdot 2048 + 2048 + 512$. النتيجة: 2,099,712. الربط بالذكاء الاصطناعي: أكبر من وحدة الانتباه.

مثال (5.39-2): نسبة FFN إلى MHA المعطيات: نفس (5.39-1). المطلوب: $N_{\text{FFN}}/N_{\text{MHA}}$. الحل: الخطوة 1: $2099712/1048576 \approx 2.0$. النتيجة: ضعفان. الربط بالذكاء الاصطناعي: FFN مهيمن على المعاملات.

مثال (5.39-3): $d_{ff} = 2d_{model}$ المعطيات: $d_{model} = 512, d_{ff} = 1024$. المطلوب: N. الحل: الخطوة 1:

$1050112 = 1048576 + 1536 = 512 + 1024 + 512 \cdot 1024 \cdot 2$. النتيجة: 1,050,112 (أقلّ). الربط بالذكاء الاصطناعي: تقليص d_{ff} يوفّر.

مثال (5.39-4): بُعد FFN الداخليّ المعطيات: $x \in \mathbb{R}^{512}$ يمرّ عبر FFN. المطلوب: بُعد بعد W_1. الحل: الخطوة 1: $W_1 : 512 \to 2048 \Rightarrow 2048$. النتيجة: 2048. الربط بالذكاء الاصطناعي: توسّع ثماني مرّات.

مثال (5.39-5): المتبقّي يحفظ الأبعاد المعطيات: $\text{Attn}(x)$ بُعده d_{model}. المطلوب: بُعد $x + \text{Attn}(x)$؟ الحل: الخطوة 1: كلاهما $d_{model} \Rightarrow$ المجموع d_{model}. النتيجة: d_{model}. الربط بالذكاء الاصطناعي: شرط ضروريّ للمتبقّي.

مثال (5.39-6): LayerNorm حسابياً المعطيات: $u = [2, 4, 6]$، $\gamma = 1, \beta = 0, \epsilon = 10^{-5}$. المطلوب: الناتج. الحل: الخطوة 1: $\mu = 4, \sigma^2 = 8/3 \approx 2.667$؛ $(u - \mu)/\sqrt{2.667} \approx [-1.225, 0, 1.225]$. النتيجة: $[-1.225, 0, 1.225]$. الربط بالذكاء الاصطناعي: تطبيع لكل عيّنة.

مثال (5.39-7): عدد معاملات LayerNorm المعطيات: $d_{model} = 512$. المطلوب: γ, β. الحل: الخطوة 1: متّجهان طولهما $512 \Rightarrow 1024$ معاملاً. النتيجة: 1024. الربط بالذكاء الاصطناعي: قليلة لكن ضرورية.

مثال (5.39-8): كتلة كاملة المعطيات: MHA + FFN + 2 LayerNorm. المطلوب: N الكتلة (بدون انحيازات مكرّرة). الحل: الخطوة 1: $1048576 + 2099712 + 2 \cdot 1024 = 3149312$. النتيجة: ~15.3 مليون. الربط بالذكاء الاصطناعي: كلفة الطبقة.

مثال (5.39-9): مقارنة بـBatchNorm المعطيات: أيّ يُستخدم في المحوّل؟ المطلوب: اشرح. الحل: الخطوة 1: LayerNorm (لا يعتمد على حجم الدفعة) $\Rightarrow$ يناسب الدُفعات الصغيرة/الطول المتغيّر. النتيجة: LayerNorm. الربط بالذكاء الاصطناعي: استقرار مستقلّ بالدفعة.

مثال (5.39-10): Pre-LN مقابل Post-LN المعطيات: هل يغيّر المعاملات؟ المطلوب: اشرح. الحل: الخطوة 1: الموضع فقط يختلف (قبل/بعد sublayer)؛ المعاملات متطابقة. النتيجة: لا تغيّر عدداً. الربط بالذكاء الاصطناعي: Pre-LN أثبت استقراراً أفضل.

مثال (5.39-11): تعقيد FFN المعطيات: n رمز، $d_{model} = 512, d_{ff} = 2048$. المطلوب: عمليّات. الحل: الخطوة 1: $2nd_{model}d_{ff} = 2 \cdot n \cdot 512 \cdot 2048 = 2.1 \times 10^6 n$ (خطّيّ في n). النتيجة: $O(nd_{model}d_{ff})$. الربط بالذكاء الاصطناعي: خطّيّ في الطول.

مثال (5.39-12): لماذا ReLU في FFN؟ المعطيات: $xW_1 + b_1 = [-1, 2, 0.5]$ قبل ReLU. المطلوب: بعد ReLU. الحل: الخطوة 1: $\max(0, \cdot) = [0, 2, 0.5]$. النتيجة: $[0, 2, 0.5]$. الربط بالذكاء الاصطناعي: عدم خطّية.

مثال (5.39-13): توفير بـd_{model} أصغر المعطيات: $d_{model} = 256, d_{ff} = 1024$. المطلوب: N_{FFN}. الحل: الخطوة 1: $525568 = 1280 + 524288 = 256 + 1024 + 2 \cdot 256 \cdot 1024$. النتيجة: 525568 (ربع السابق). الربط بالذكاء الاصطناعي: مربّع في d_{model}.

مثال (5.39-14): تنشيط بديل GELU المعطيات: استبدال ReLU بـGELU. المطلوب: هل تتغيّر المعاملات؟ الحل: الخطوة 1: التنشيط لا أوزان $\Rightarrow N$ ثابتة. النتيجة: لا. الربط بالذكاء الاصطناعي: GELU أفضل عمليّاً.

مثال (5.39-15): التحقّق من أبعاد W_2 المعطيات: $d_{model} = 512 \to d_{ff} = 2048$. المطلوب: أبعاد W_2. الحل: الخطوة 1: $W_2 \in \mathbb{R}^{2048 \times 512}$. النتيجة: 512×2048. الربط بالذكاء الاصطناعي: ضغط العودة.

أخطاء شائعة

- **الخلط بين LayerNorm وBatchNorm:** الأول لكل عيّنة لا دفعة.
- **نسيان أن FFN مهيمن على المعاملات:** أكبر من الانتباه.
- **كسر شرط البُعد في المتبقّي:** يجب تطابق الأبعاد.

- **إهمال γ, β:** معاملات تطبيع قابلة للتعلّم.
- **ظنّ Pre/Post-LN يغيّر عدد المعاملات:** يغيّر الاستقرار فقط.

صياغة رسمية: لتسلسل طوله n وبُعد d، تعقيد الانتباه

$$C_{\text{attn}} = O(n^2 d) \tag{7.39}$$

يُطبَّق القناع بإضافة $-\infty$ (قبل softmax) على الخلايا المحظورة:

$$A_{ij} = \begin{cases} \frac{q_i \cdot k_j}{\sqrt{d_k}} & \text{مسموح} \\ -\infty & \text{محظور} \end{cases} \tag{8.39}$$

فيعطي softmax وزناً صفريّاً للمحظور.

جدول الرموز

الرمز	المعنى
n	طول المتسلسلة
A	خريطة الانتباه $n \times n$
قناع سببيّ	يمنع رؤية المستقبل
قناع حشو	يستبعد رموز PAD

الرسم

<figure> الشكل 6.39 </figcaption>: القناع السببيّ (مثلّث سفلي) يمنع الرمز من رؤية ما بعده؛ قناع الحشو يستبعد رموز PAD. </figcaption> </figure>

البرهان

الخطوة 1 (تعقيد الانتباه): ضرب $QK^\top$ يحتاج $n \cdot n \cdot d$؛ softmax وضرب AV اختصاراً $O(n^2 d)$ كليّاً. ■

الخطوة 2 (القناع السببيّ): للمولّد التلقائيّ، الرمز i يجب ألّا ينتبه لـ $j > i \Rightarrow$ تعيين المثلّث العلويّ $-\infty$. ■

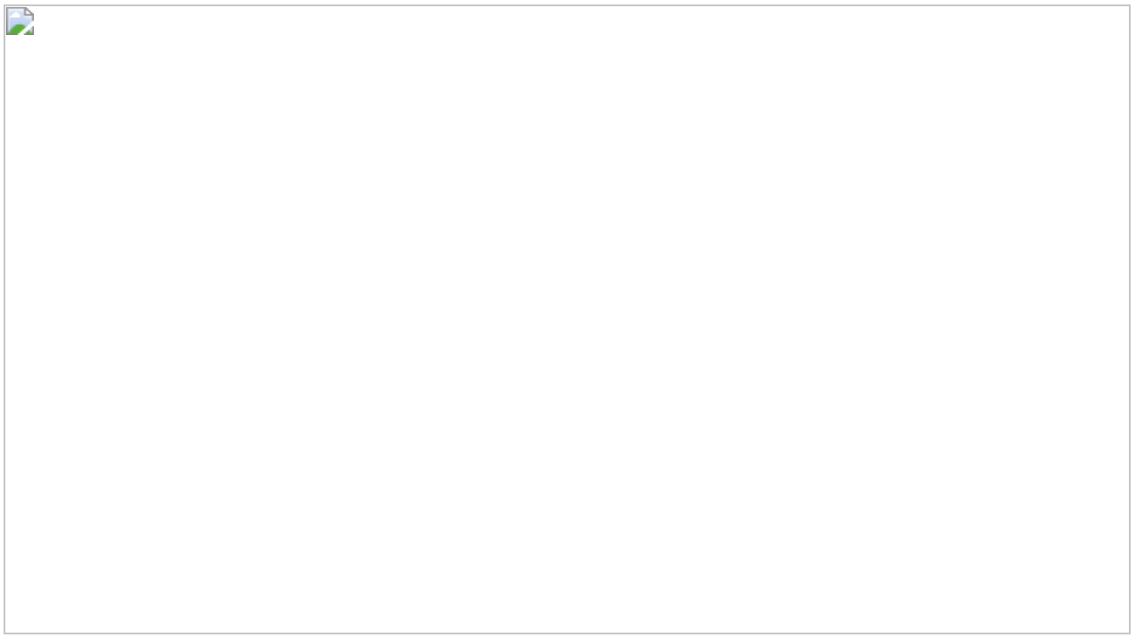
الخطوة 3 (قناع الحشو): رموز PAD بلا معنى $\Rightarrow$ نُصفّر أوزانها حتى لا تؤثّر على التجميع. ■

خمسة عشر مثالاً محلولاً

مثال (6.39-1): تعقيد لـ $n = 1000, d = 512$ المعطيات: $n = 1000, d = 512$. المطلوب: C_{attn} تقريباً. الحل: الخطوة 1: $1000^2 \cdot 512 = 5.12 \times 10^8$. النتيجة: ~512 مليون. الربط بالذكاء الاصطناعي: n^2 ينفخ بسرعة.

مثال (6.39-2): قناع سببيّ 4×4 المعطيات: $n = 4$ منع المستقبل. المطلوب: أي خلايا محظورة؟ الحل: الخطوة 1: (i, j) مع $j > i$ محظورة: (0,1),(0,2),(0,3),(1,2),(1,3),(2,3). النتيجة: 6 خلايا. الربط بالذكاء الاصطناعي: مثلّث علويّ.

مثال (6.39-3): softmax مع $-\infty$ المعطيات: $[2, -\infty]$. المطلوب: الأوزان. الحل: الخطوة 1: $e^{-\infty} = 0$؛ $(e^2 + 0) \Rightarrow [1, 0]$. النتيجة: $[1, 0]$. الربط بالذكاء الاصطناعي: المحظور يصفر.



شكل ٥.٣٩: *
القناع

مثال (4-6.39): قناع حشو المعطيات: تسلسلة فعلية طولها 3 + PAD واحد. المطلوب: كيف نتعامل مع PAD؟ الحل: الخطوة 1: نضع قناعاً يجعل وزن الصفّ/العمود PAD = 0. النتيجة: لا مساهمة. الربط بالذكاء الاصطناعي: حشو قناعيّ.

مثال (5-6.39): مقارنة مع RNN المعطيات: RNN تعقيد $O(nd^2)$. المطلوب: متى الانتباه أغلى؟ الحل: الخطوة 1: الانتباه $O(n^2 d)$ يتفوّق عند $n > d$. النتيجة: تسلسلات طويلة $\Rightarrow$ أغلى. الربط بالذكاء الاصطناعي: دافع استخدام الانتباه الفعّال.

مثال (6-6.39): ذاكرة خريطة الانتباه المعطيات: $n = 512$. المطلوب: عناصر A. الحل: الخطوة 1: $512^2 = 262144$. النتيجة: ~262 ألف. الربط بالذكاء الاصطناعي: عنق زجاجة الذاكرة.

مثال (7-6.39): قناع ثنائيّ الاتجاه (مشفّر) المعطيات: BERT يرى الكلّ. المطلوب: هل يُستخدم قناع سببيّ؟ الحل: الخطوة 1: لا، المشفّر غير سببيّ $\Rightarrow$ كلّ الأزواج مسموحة. النتيجة: بلا قناع سببيّ. الربط بالذكاء الاصطناعي: BERT ثنائيّ الاتجاه.

مثال (8-6.39): تعقيد كامل طبقة المعطيات: انتباه + FFN. المطلوب: C_{layer}. الحل: الخطوة 1: $O(n^2 d + nd^2)$، المهيمن $n^2 d$ لـ $n > d$. النتيجة: $O(n^2 d)$ غالباً. الربط بالذكاء الاصطناعي: الانتباه يطغى.

مثال (9-6.39): تسلسل مزدوج الطول المعطيات: $n : 100 \to 200$. المطلوب: نسبة التعقيد. الحل: الخطوة 1: $(200/100)^2 = 4$. النتيجة: ×4. الربط بالذكاء الاصطناعي: تربيعيّ حادّ.

مثال (10-6.39): القناع والدقّة العددية المعطيات: نستخدم -10^9 بدل $-\infty$. المطلوب: تأثير softmax؟ الحل: الخطوة 1: $e^{-10^9} \approx 0$ عملياً $\Rightarrow$ وزن صفريّ. النتيجة: مكافئ. الربط بالذكاء الاصطناعي: تفادي inf- في الحساب.

مثال (11-6.39): قناع مستقبلي في الترجمة المعطيات: فكّ التشفير يولّد رمزاً تلو الآخر. المطلوب: لماذا القناع السببيّ؟ الحل: الخطوة 1: أثناء التوليد الرمز $t + 1$ غير موجود بعد $\Rightarrow$ منعه يمنع تسريب الإجابة. النتيجة: ضروريّ للتدريب. الربط بالذكاء الاصطناعي: منع تسريب الإجابة.

مثال (12-6.39): تعقيد متعدّد الطبقات المعطيات: $L = 12$ طبقة. المطلوب: C_{total}. الحل: الخطوة 1:

$O(n^2 d)$ · 12. النتيجة: ×12. الربط بالذكاء الاصطناعي: يتضاعف خطّيّاً بالعمق.

مثال (13-6.39): mask padding في batch المعطيات: تسلسلات بأطوال مختلفة تُملأ بـPAD. المطلوب: معالجة؟ الحل: الخطوة 1: قناع لكل عيّنة يستبعد مواقع PAD قبل softmax. النتيجة: لا تلويث. الربط بالذكاء الاصطناعي: تدريب batched.

مثال (14-6.39): مقارنة $n^2 d$ مع nd^2 لـ $n = d = 512$ المعطيات: $n = d = 512$. المطلوب: أي أكبر؟ الحل: الخطوة 1: كلاهما $512^3 \approx 1.34 \times 10^8$ (متساويان). النتيجة: متطابقان هنا. الربط بالذكاء الاصطناعي: نقطة التعادل.

مثال (15-6.39): تبرير القناع رياضيّاً المعطيات: $A = \text{softmax}(S + M)$، M قناع $\in \{0, -\infty\}$. المطلوب: أثر M. الحل: الخطوة 1: $\exp(S_{ij} + M_{ij}) = \exp(S_{ij}) \cdot \exp(M_{ij})$؛ $\exp(-\infty) = 0 \Rightarrow$ تحييد. النتيجة: حجب تامّ. الربط بالذكاء الاصطناعي: أساس التنفيذ.

أخطاء شائعة

- **نسيان القناع السببيّ في فكّ التشفير:** تسريب الإجابة.
- **الخلط بين قناع الحشو والسببيّ:** أغراض مختلفة.
- **ظنّ تعقيد الانتباه خطّيّ:** هو $O(n^2 d)$ تربيعيّ في الطول.
- **استخدام 0 بدل $-\infty$ في القناع:** يعطي وزناً صغيراً لا صفريّاً.
- **إهمال أن القناع يُطبَّق قبل softmax:** بعده لا يعمل.

صياغة رسمية: في فكّ التشفير، الانتباه المتقاطع يأخذ

$$Q = H_{\text{dec}} W^Q, \qquad K = H_{\text{enc}} W^K, \qquad V = H_{\text{enc}} W^V \tag{9.39}$$

بحيث Q من الحالة المولَّدة وK, V من المشفّر. والتوليد التلقائيّ يُنتج $y_t \sim p(y_t \mid y_{<t}, x)$ بخطوة واحدة كلّ مرّة.

جدول الرموز

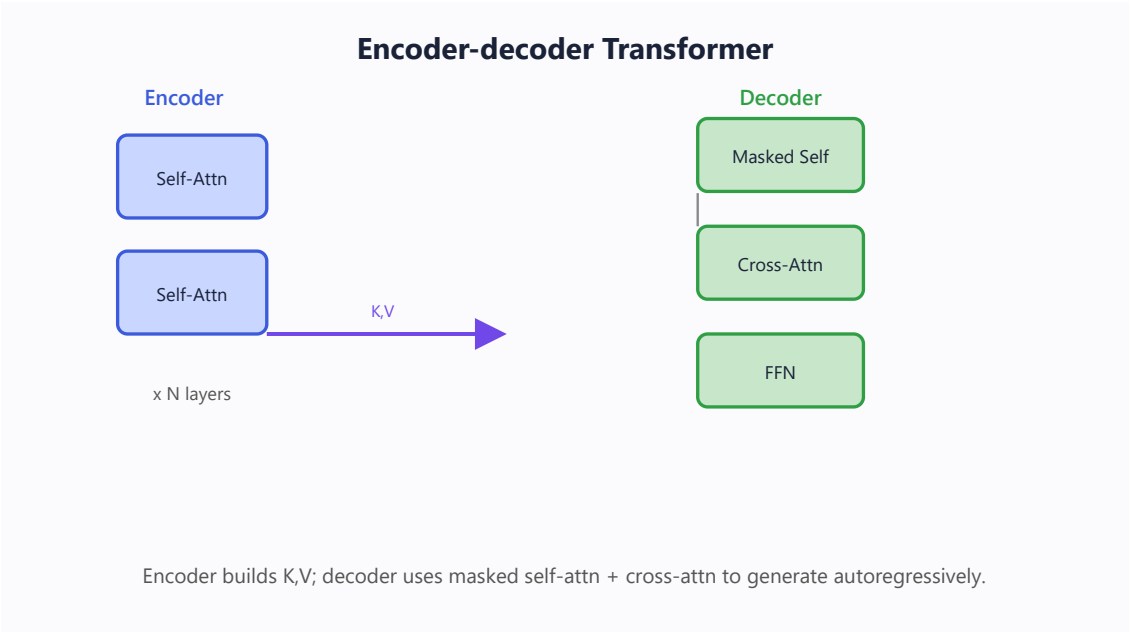
الرمز	المعنى
H_{enc}	مخرجات المشفّر
H_{dec}	حالة فكّ التشفير
$y_{<t}$	الرموز المولَّدة سابقاً

الرسم

<figure> الشكل<figcaption> 5.39: المشفّر يولّد K, V؛ فكّ التشفير يستخدم Q من حالته وK, V من المصدر عبر الانتباه المتقاطع.</figcaption> </figure>

البرهان

الخطوة 1 (مصادر مختلفة): الانتباه الذاتيّ Q, K, V من نفس التسلسلة؛ المتقاطع يفصل Q (الهدف) عن K, V (المصدر). ■



شكل ٦.٣٩: *
المشفّر-فك التشفير

الخطوة 2 (الاسترجاع): كلّ رمز هدف "يبحث" في المصدر عن السياق المناسب عبر أوزان الانتباه. ■

الخطوة 3 (التوليد): y_t يعتمد شرطيّاً على $y_{<t}$ ⇒ سلسلة ماركوفيّة تُولَّد تدريجيّاً (autoregressive). ■

خمسة عشر مثالاً محلولاً

مثال (1-7.39): أبعاد cross-attn المعطيات: $H_{\text{enc}} \in \mathbb{R}^{n\times d}, H_{\text{dec}} \in \mathbb{R}^{m\times d}$. المطلوب: بُعد الناتج. الحل: الخطوة 1: $Q \in \mathbb{R}^{m\times d}, K,V \in \mathbb{R}^{n\times d}$؛ الناتج $m\times d$. النتيجة: $m\times d$. الربط بالذكاء الاصطناعي: طول الهدف m مستقلّ.

مثال (2-7.39): عدد المعاملات المعطيات: $d=512$ (نفس MHA). المطلوب: N cross-attn. الحل: الخطوة 1: مثل MHA: $4d^2 = 1048576$. النتيجة: ~1.05 مليون. الربط بالذكاء الاصطناعي: وحدة إضافية في فكّ التشفير.

مثال (3-7.39): متى يُستخدم؟ المعطيات: ترجمة آلية. المطلوب: دور المتقاطع. الحل: الخطوة 1: يربط كلّ كلمة مولَّدة بالكلمات المصدرية المناسبة. النتيجة: محاذاة ناعمة. الربط بالذكاء الاصطناعي: بديل المحاذاة الصلبة.

مثال (4-7.39): توليد أوّل رمز المعطيات: $y_0 =$ <BOS>. المطلوب: ماذا يرى فكّ التشفير؟ الحل: الخطوة 1: Q من <BOS> فقط؛ ينتبه إلى كلّ H_{enc}. النتيجة: سياق المصدر الكامل. الربط بالذكاء الاصطناعي: نقطة البداية.

مثال (5-7.39): تعقيد التوليد المعطيات: تسلسل هدف طوله m. المطلوب: C. الحل: الخطوة 1: $O(m^2 d + mnd)$ (ذاتيّ + متقاطع). النتيجة: تربيعيّ في m وخطّيّ في n. الربط بالذكاء الاصطناعي: يكبر مع الطولين.

مثال (6-7.39): search beam المعطيات: نحتفظ بـ5 مسارات. المطلوب: كيف يستفيد المتقاطع؟ الحل: الخطوة 1: كلّ مسار يستخدم نفس K,V المصدر ⇒ حساب مشترك. النتيجة: كفاءة. الربط بالذكاء الاصطناعي: تقييم متوازٍ.

مثال (7-7.39): الانتباه الذاتيّ مقابل المتقاطع المعطيات: أيّهما في المشفّر؟ الحل: الخطوة 1: المشفّر ذاتيّ فقط (K,V خارجيّة). النتيجة: ذاتيّ. الربط بالذكاء الاصطناعي: تقسيم الأدوار.

مثال (8-7.39): رمز <EOS> المعطيات: متى ينتهي التوليد؟ الحل: الخطوة 1: عند أرجح $y_t =< EOS >$ تتوقّف. النتيجة: إنهاء. الربط بالذكاء الاصطناعي: شرط التوقّف.

مثال (9-7.39): صيغة الاحتمال المعطيات: نموذج لغوي شرطيّ. المطلوب: $p(y_t \mid \cdot)$. الحل: الخطوة 1: $p(y_t \mid$

$y_{<t}, x) = \text{softmax}(W_o h_t^{\text{dec}})_{y_t}$. النتيجة: توزيع على المفردات. الربط بالذكاء الاصطناعي: cross-entropy هدف.

مثال (39.7-10): تبعّع طويل المعطيات: جملة مصدر 100 كلمة. المطلوب: هل يرى الهدف الكلّ؟ الحل: الخطوة 1: نعم، K, V كلّ المصدر متاح ⇒ لا عنق زجاجة كـseq2seq القديم. النتيجة: سياق كامل. الربط بالذكاء الاصطناعي: ميزة المحوّف.

مثال (39.7-11): أخطاء التوليد المعطيات: التدريب بـforcing ،teacher المطلوب: هل يستخدم المتقاطع الحقيقيّ؟ الحل: الخطوة 1: نعم، المتقاطع يأخذ H_{enc} لا $y_{<t}$؛ forcing teacher يؤثّر فقط على Q الذاتيّ. النتيجة: مستقلّ. الربط بالذكاء الاصطناعي: فصل التدريب/الاختبار.

مثال (39.7-12): تقليل m المعطيات: ملخّص نصّ طويل إلى جملة. المطلوب: $n \gg m$. الحل: الخطوة 1: $C = O(m^2 d + mnd)$ مع m صغير ⇒ مهيمن mnd. النتيجة: خطّيّ في n. الربط بالذكاء الاصطناعي: الملخّصات قصيرة الهدف.

مثال (39.7-13): تطبيق غير لغويّ المعطيات: رؤية-لغة ،(captioning) المطلوب: H_{enc}؟ الحل: الخطوة 1: من CNN لا نصّ ⇒ المتقاطع يربط الكلمات بميزات الصورة. النتيجة: ،captioning الربط بالذكاء الاصطناعي:cross-modal.

مثال (39.7-14): ثبات K, V أثناء التوليد المعطيات: خطوة بخطوة. المطلوب: هل تُعاد حساب K, V؟ الحل: الخطوة 1: لا، H_{enc} ثابت ⇒ نحسب K, V مرّة. النتيجة: كفاءة. الربط بالذكاء الاصطناعي: تخزين مؤقّت.

مثال (39.7-15): مقارنة مع seq2seq RNN المعطيات: أيهما يرى السياق الكامل؟ الحل: الخطوة 1: المحوّف عبر المتقاطع يرى كلّ المصدر في كلّ خطوة؛ RNN مضغوط في c فقط. النتيجة: المحوّف أغنى. الربط بالذكاء الاصطناعي: تفوق المحوّف.

أخطاء شائعة

- **الخلط بين الذاتيّ والمتقاطع:** مصادر Q vs K, V مختلفة.
- **ظنّ K, V من فكّ التشفير في المتقاطع:** هي من المشفّر.
- **إهمال التوليد التلقائيّ:** يبطئ الاستدلال (رمزًا تلو الآخر).
- **نسيان <EOS>:** لا توقّف.
- **اعتبار المتقاطع مكلفاً كالذاتيّ:** $O(mn)$ لا m^2 غالباً.

صياغة رسمية: الانتباه الكاملّ $O(n^2 d)$ يُخفَّض بإحدى طرق:

- **متفرّق (Sparse):** كلّ رمز ينتبه لِـ$k \ll n$ جيران/عالمات ⇒ $O(nkd)$.
- **Linformer:** إسقاط K, V إلى بُعد k ⇒ $O(nkd)$.
- **Performer:** تقريب softmax بِميزات عشوائية ⇒ $O(nd^2)$ لا n^2.

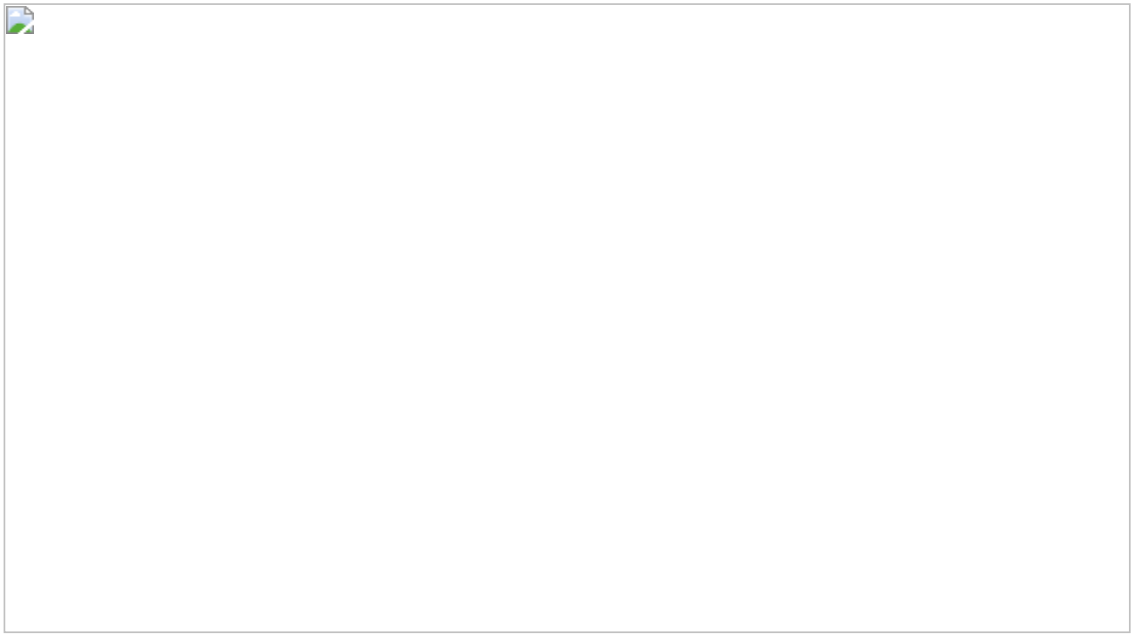
فبشكل عام للوصول إلى $O(n)$ أو $O(n \log n)$ في n.

جدول الرموز

الرمز	المعنى
k	بُعد/عدد الجيران المُختَزَل
n	طول المتسلسلة
$O(n^2 d)$	تعقيد الانتباه الكاملّ

الرسم

<figure> الشكل<figcaption> 7.39: يسار كامل n^2، يمين نسخة متفرّقة/منخفضة الرتبة تربط أزواجاً



شكل ٧.٣٩: *
الانتباه الفعال

أقلّ.</figcaption> </figure>

البرهان

الخطوة 1 (Linformer): إسقاط K, V عبر $E \in \mathbb{R}^{n \times k}$ يجعل الحساب $O(nkd)$ مع $k \ll n$. ■

الخطوة 2 (Performer): $\exp(q \cdot k) \approx \phi(q) \cdot \phi(k)$ (تقريب نواة إيجابيّة) $\Rightarrow$ لا حاجة لخريطة $n \times n$. ■

الخطوة 3 (Sparse): قصر كلّ صفّ على k إدخالاً $\Rightarrow nk$ بدل n^2. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.39): Linformer بـ$k = 64$ المعطيات: $n = 4096, d = 512$. المطلوب: نسبة التوفير. الحل: الخطوة 1: كامل $4096^2 \cdot 512 \approx 8.6 \times 10^9$؛ Linformer $4096 \cdot 64 \cdot 512 \approx 1.34 \times 10^8$؛ النسبة 64. النتيجة: ×64 أوفر. الربط بالذكاء الاصطناعي: طويل جدّاً.

مثال (2-8.39): Performer تعقيد المعطيات: $n = 10000, d = 256$. المطلوب: C. الحل: الخطوة 1: $10000 \cdot 256^2 \approx 6.55 \times 10^8$ لا $O(nd^2) = 6.55 \times 10^{10}$. النتيجة: ×100 أوفر. الربط بالذكاء الاصطناعي: خطّيّ في n.

مثال (3-8.39): Sparse محليّ المعطيات: نافذة $k = 128$ لكلّ رمز. المطلوب: روابط لـ$n = 2000$. الحل: الخطوة 1: $2000 \cdot 128 = 256000$ لا 4×10^6. النتيجة: ×6.15 أقل. الربط بالذكاء الاصطناعي: نمط النافذة.

مثال (4-8.39): متى تخسر الدقّة؟ المعطيات: مهامّ تتطلّب سياقاً عالمياً. المطلوب: خطر. الحل: الخطوة 1: sparse المترجِم جيراناً قد يفوت علاقات بعيدة ⇒ تحتاج روابط عالمية. النتيجة: توازن. الربط بالذكاء الاصطناعي: هجين محليّ+عالميّ.

مثال (5-8.39): توفير الذاكرة المعطيات: خريطة $n \times n$ لـ$n = 8192$. المطلوب: عناصر. الحل: الخطوة 1: $8192^2 \approx 6.7 \times 10^7$ (67 مليون) لا تُحتمل غالباً. النتيجة: تحتاج فعّالية. الربط بالذكاء الاصطناعي: عنق ذاكرة حقيقيّ.

مثال (6-8.39): تقريب النواة المعطيات: Performer بِميزات $m = 256$. المطلوب: دقّة؟ الحل: الخطوة 1: m أكبر ⇒ تقريب أدقّ على حساب $O(nmd)$. النتيجة: مفاضلة. الربط بالذكاء الاصطناعي: عدد الميزات العشوائية.

مثال (7-8.39): مقارنة ثلاثية المعطيات: $n = 1024, d = 512$. المطلوب: رتّب التعقيد. الحل: الخطوة 1: كامل $O(n^2 d)$؛ Linformer $O(nkd)$؛ Performer $O(nd^2)$؛ لـ$n > d$ كامل أسوأ. النتيجة: كامل > البقية. الربط بالذكاء الاصطناعي: دافع البدائل.

مثال (8-8.39): Attention Flash المعطيات: لا يقلّل n^2 نظرياً لكن يقلّل نقل الذاكرة. المطلوب: كيف؟ الحل: الخطوة 1: يحسب الكتل (tiles) على SRAM سريع ⇒ أقل قراءة/كتابة HBM. النتيجة: أسرع فعلياً لا أقلّ تعقيد. الربط بالذكاء الاصطناعي: تحسين IO لا خوارزميّ.

مثال (9-8.39): BigBird المعطيات: يجمع نافذة + عالميّات + عشوائيّ. المطلوب: تعقيد. الحل: الخطوة 1: $O(n)$ لكلّ رمز عدد ثابت من الروابط. النتيجة: $O(n)$. الربط بالذكاء الاصطناعي: sparse هجين.

مثال (10-8.39): تطبيق على الجينوم المعطيات: تسلسل $n = 10^6$. المطلوب: أي طريقة؟ الحل: الخطوة 1: كامل مستحيل؛ sparse/performer ضروريّ. النتيجة: فعّال حتميّ. الربط بالذكاء الاصطناعي: علم الأحياء الطويل.

مثال (11-8.39): خطأ التقريب Linformer المعطيات: k صغير جدّاً. المطلوب: أثر. الحل: الخطوة 1: ضغط K, V يفقد معلومة ⇒ دقّة أقلّ. النتيجة: مفاضلة k. الربط بالذكاء الاصطناعي: اختيار k بحذر.

مثال (12-8.39): مقارنة مع محوّف كامل للدقّة المعطيات: مهمّة GLUE. المطلوب: هل الفعّال يضاهي؟ الحل: الخطوة 1: Linformer/Performer قريبة ضمن 1% لـn معتدل. النتيجة: مقاربة. الربط بالذكاء الاصطناعي: مقايضة مقبولة.

مثال (13-8.39): تعقيد التدرّج المعطيات: هل التدرّج يبقى رخيصاً؟ الحل: الخطوة 1: نفس البنية المُخفَّضة ⇒ التدرّج بنفس رتبة الأمام. النتيجة: نعم. الربط بالذكاء الاصطناعي: فائدة شاملة.

مثال (14-8.39): Longformer المعطيات: نافذة + انتباه عالميّ منتقى. المطلوب: تعقيد. الحل: الخطوة 1: $O(nw + ng)$ مع w عرض النافذة، g العالميّات. النتيجة: $O(n)$. الربط بالذكاء الاصطناعي: مستندات طويلة.

مثال (15-8.39): متى نبقى كاملين؟ المعطيات: $n \leq 512$. المطلوب: قرار. الحل: الخطوة 1: $n^2 d$ محتمل ⇒ المحوّف الكامل أبسط وأدقّ. النتيجة: كامل يكفي. الربط بالذكاء الاصطناعي: التكلفة تحدّد الاختيار.

أخطاء شائعة

- **ظنّ البدائل مجّانيّة الدقّة:** تقريب يخسر معلومة.
- **الخلط بين Flash (IO) والفعّال (خوارزميّ):** يحلّان مشكلتين مختلفتين.
- **اختيار k صغير جدّاً:** ضغط مفرط.

- **توقّع** $O(n)$ **دائماً:** Performer $O(nd^2)$ خطّيّ في n لا n^2 **فقط.**
- **إهمال أن المحوّف الكامل أفضل للأطوال القصيرة.**

جدول تجميعي لنظريات الفصل

النظرية	العنوان	الصيغة المحوريّة
2.39	الانتباه المُقاس	$\text{Attn} = \text{softmax}(QK^\top/\sqrt{d_k})V$
3.39	تعدّد الرؤوس	$\text{head}_i = \text{Attn}(QW_i^Q, KW_i^K, VW_i^V)$
4.39	الترميز الموضعيّ	$PE_{pos,2i} = \sin(pos/10000^{2i/d})$
5.39	كتلة المحوّف	$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$
6.39	التعقيد والقناع	$C_{\text{attn}} = O(n^2 d)$
7.39	الانتباه المتقاطع	$Q = H_{dec}W^Q,\ K, V = H_{enc}W^{K,V}$
8.39	الانتباه الفعّال	$O(n)$ Linformer/Performer أو $O(nd^2)$

عشرون تمريناً مع الإجابات

١. **(تمرين)** $Q \in \mathbb{R}^{3\times4}, K \in \mathbb{R}^{5\times4}, V \in \mathbb{R}^{5\times6}$ احسب بُعد الناتج. **إجابة:** 3×6.

٢. **(تمرين)** $d_k = 64$، نقطة 8 =، احسب المُقاس. **إجابة:** $8/\sqrt{64} = 1$.

٣. **(تمرين)** $d_{model} = 512, h = 8$ احسب N_{MHA}. **إجابة:** $4 \cdot 512^2 = 1048576$.

٤. **(تمرين)** d_k لـ $h = 8$؟ **إجابة:** $512/8 = 64$.

٥. **(تمرين)** أثبت أن التقريب بـ$\sqrt{d_k}$ يبقى softmax معتدلاً. **إجابة:** يحدّ تباين الدرجات.

٦. **(تمرين)** $PE_{(1,0)}$ لـ $d = 512$. **إجابة:** $\sin(1) \approx 0.841$.

٧. **(تمرين)** $d_{model} = 512, d_{ff} = 2048$ احسب N_{FFN}. **إجابة:** $2 \cdot 512 \cdot 2048 + 2048 + 512 = 2099712$.

٨. **(تمرين)** مقارنة FFN/MHA. **إجابة:** FFN ≈ ضعفان.

٩. **(تمرين)** $n = 1000, d = 512$ احسب C_{attn}. **إجابة:** $1000^2 \cdot 512 = 5.12 \times 10^8$.

١٠. **(تمرين)** قناع سببيّ $n = 4$ كم خلية محظورة؟ **إجابة:** 6.

١١. **(تمرين)** لماذا LayerNorm لا BatchNorm؟ **إجابة:** مستقلّ بالدفعة.

١٢. **(تمرين)** cross-attn Q من أين؟ **إجابة:** فكّ التشفير (H_{dec}).

١٣. **(تمرين)** Linformer $n = 4096, k = 64$ نسبة التوفير. **إجابة:** ×64.

١٤. **(تمرين)** Performer تعقيد. **إجابة:** $O(nd^2)$.

١٥. **(تمرين)** softmax من $[2, -\infty]$؟ **إجابة:** $[1, 0]$.

١٦. **(تمرين)** هل h يزيد معاملات MHA؟ **إجابة:** لا (مع $d_k = d_{model}/h$).

١٧. **(تمرين)** PE هل تُعلَّم؟ **إجابة:** الجيبيّة لا.

١٨. **(تمرين)** متى المحوّف الكامل أفضل؟ **إجابة:** $n \leq 512$ تقريباً.

١٩. **(تمرين)** cross-attn K, V من أين؟ **إجابة:** المشفّر (H_{enc}).

٢٠. **(تمرين)** لماذا المحوّف أسرع تدريباً من RNN؟ **إجابة:** موازاة كاملة بلا تبعّع زمنيّ.

فهرس الرموز

- Q, K, V — الاستعلام/المفتاح/القيمة.
- d_k, d_v, d_{model}, h — أبعاد الانتباه وعدد الرؤوس.
- PE — الترميز الموضعيّ.
- d_{ff} — بُعد FFN الداخليّ.
- A — خريطة الانتباه (قبل/بعد softmax).
- H_{enc}, H_{dec} — مخرجات المشفّر/فكّ التشفير.

المراجع

- A. Vaswani, et al. *Attention Is All You Need* (Transformer).
- J. Devlin, et al. *BERT* (encoder-only, bidirectional).
- A. Radford, et al. *GPT* (decoder-only, autoregressive).
- R. Child, et al. *Generating Long Sequences with Sparse Transformers*.
- S. Wang, et al. *Linformer*.
- K. Choromanski, et al. *Performer* (random feature attention).
- Ba, J., Kiros, R., Hinton G. *Layer Normalization*.

<!-- نهاية الفصل التاسع والثلاثون -->

نواة التماس العصبية (Neural Tangent Kernel)

«في العرض اللانهائيّ، لا يتعلّم العصبونُ ميزاتٍ جديدة، بل يحلّ معادلة رياضيةً خطّيةً فوق نواةٍ ثابتة.»

بعد أن درسنا بنية المحوّفات، نتساءل: هل يمكن وصف تدريب شبكة عصبية بِمعادلةٍ مغلقة؟ نواة التماس العصبية (NTK) تجيب: عند العرض اللانهائيّ، تجمد نواةُ التدريب عند القيمة الابتدائية، فيصبح التدريب مكافئاً لانحدار نوويّ (kernel regression). هذا الفصل يُثبِتُ تعريف النواة، ديناميكا التدريب، الحلّ المغلق، علاقتها بـNNGP، نسخة الالتفاف، ومحدوديّتها.
سبع نظريات:

- **2.40 تعريف NTK** — $\Theta(x,x') = \langle \nabla_\theta f(x), \nabla_\theta f(x') \rangle$ (متوقَّعة).
- **3.40 معادلة تطوّر التدريب** — $\partial_t f_i = \sum_j \Theta_{ij}(f_j - y_j)$.
- **4.40 تجميد العرض اللانهائيّ** — $\Theta(t) \to \Theta(0)$ ثابتة.
- **5.40 الحلّ المغلق وتقارب الخطأ** — $f(t) - y = e^{-\Theta(0)\,t}\,(f(0) - y)$.
- **6.40 علاقة NTK بـNNGP** — النواة مقابل التوزيع الأوليّ.
- **7.40 النواة الالتفافية (ConvNTK)** — تكافؤ الترجمة.
- **8.40 محدوديّة NTK والتعلّم الميزاتيّ** — نظام النواة مقابل تطوّر الميزات.

كل نظرية تتبع القالب الرباعي: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
$f(x;\theta)$	خرج الشبكة	معاملات θ
$\Theta(x,x')$	نواة التماس	مصفوفة $n \times n$ على البيانات
$\mathcal{N}$	توزيع التهيئة	غوسي عشوائيّ
t	زمن التدريب (gradient flow)	لا يرتبط بزمن RNN
NNGP	Process Gaussian للشبكة	التوزيع الأوليّ
ρ	جيب التمام (تشابه)	$\rho = \frac{x^\top x'}{\|x\|\|x'\|}$

الافتراضات: المخرجات مُفترضة قياسيّة (scalar) لتبسيط النواة؛ التهيئة الغوسيّة القياسيّة؛ كلّ المعادلات في كتل LTR.

صياغة رسمية: لشبكة بِمخرج $f(x;\theta)$ ومعاملات θ، نواة التماس عند زوج المدخلات (x, x') هي الجداء الداخليّ لمتّجهات التدرّج

$$\Theta(x, x'; \theta) = \Big\langle \nabla_\theta f(x;\theta),\ \nabla_\theta f(x';\theta) \Big\rangle_{\mathbb{R}^{|\theta|}} \tag{1.40}$$

وعند العرض اللانهائيّ نأخذ التوقّع فوق تهيئة $\theta \sim \mathcal{N}$:

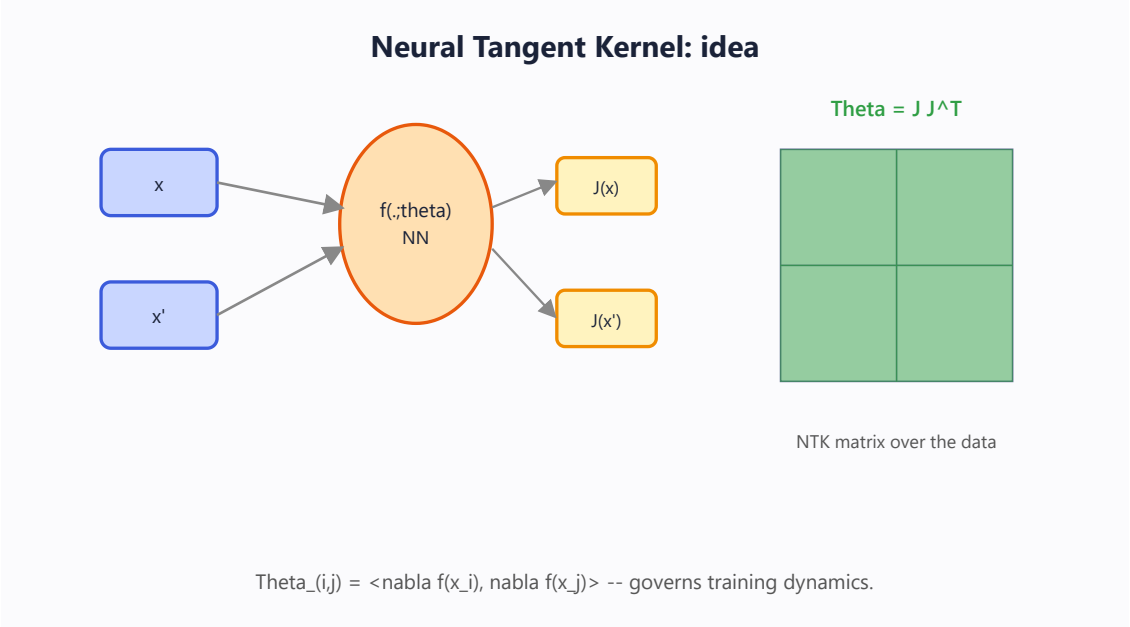
$$\Theta(x, x') = \mathbb{E}_\theta\big[\Theta(x, x'; \theta)\big] \tag{2.40}$$

جدول الرموز

الرمز	المعنى
$\nabla_\theta f$	تدرّج الخرج بالنسبة للمعاملات
$\langle \cdot, \cdot \rangle$	جداء داخليّ أورثوغونيّ
$\mathbb{E}_\theta$	توقّع التهيئة

الرسم

<figure> الشكل<figcaption> 1.40: الجاكوبيات $J(x), J(x')$ تُكوّن النواة $JJ^\top$ = Θ فوق بيانات



شكل ١.٤٠: *
مفهوم NTK

التدريب.</figcaption> </figure>

البرهان

الخطوة 1 (الجاكوبيّ): $\nabla_\theta f(x)$ متّجه طوله $|\theta|$؛ جداؤه الداخليّ مع نظيره عند x' يقيس مدى تأثّر الخرجين بنفس المعاملات. ■

الخطوة 2 (الارتباط): إن كانا يتأثّران معاً، فالتغيير في θ يحرّك $f(x), f(x')$ معاً $\Rightarrow$ ارتباط عبر النواة. ■

الخطوة 3 (التوقّع): التهيئة العشوائيّة تجعل Θ عشوائيّاً؛ نأخذ متوسطه لتثبيته تحليليّاً. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.40): عصبون خطّيّ بلا انحياز المعطيات: $f(x;\theta) = \theta^\top x$، $\theta \in \mathbb{R}^d$. المطلوب: $\Theta(x, x')$. الحل: الخطوة 1: $\nabla_\theta f(x) = x$ (لا يعتمد θ). الخطوة 2: $\Theta(x, x') = \langle x, x' \rangle = x^\top x'$. النتيجة: $x^\top x'$ (مستقلّ عن θ!).

الربط بالذكاء الاصطناعي: أبسط نواة خطّية.

مثال (2-2.40): حالة $x = x'$ المعطيات: نفس (1-2.40)، $x = x'$. المطلوب: $\Theta(x,x)$. الحل: الخطوة 1: $x^\top x = \|x\|^2$. النتيجة: $\|x\|^2$. الربط بالذكاء الاصطناعي: القطر مربّع النموذج.

مثال (3-2.40): متعامدان المعطيات: $x \perp x'$. المطلوب: Θ. الحل: الخطوة 1: $x^\top x' = 0$. النتيجة: 0 (لا ارتباط). الربط بالذكاء الاصطناعي: مدخلات مستقلّة تماماً.

مثال (4-2.40): نواة ReLU من طبقتين (صيغة معروفة) المعطيات: شبكة ReLU عرض لانهائيّ، طبقة مخفية واحدة. المطلوب: $\Theta(x,x')$ القياسيّ. الحل: الخطوة 1: $\Theta(x,x') = \frac{x^\top x'}{2} + \frac{\|x\|\|x'\|}{2\pi}(\pi - \arccos\rho)$، $\rho = \frac{x^\top x'}{\|x\|\|x'\|}$. النتيجة: الصيغة القياسيّة. الربط بالذكاء الاصطناعي: NTK لشبكة عميقة-ضحلة.

مثال (5-2.40): حساب عدديّ لـNTK ReLU المعطيات: $x = [1,0], x' = [1,1]/\sqrt{2}$. المطلوب: Θ. الحل: الخطوة 1: $\|x\| = 1, \|x'\| = 1, x^\top x' = 1/\sqrt{2} \Rightarrow \rho = 1/\sqrt{2}, \arccos(1/\sqrt{2}) = \pi/4$. الخطوة 2: $\Theta = \frac{0.7071}{2} + \frac{1}{2\pi}(\pi - \pi/4) = 0.3536 + \frac{3}{8} = 0.3536 + 0.375 = 0.7286$. النتيجة: 0.7286. الربط بالذكاء الاصطناعي: نواة لا خطّية.

مثال (6-2.40): متساوٍ تماماً في ReLU المعطيات: $x = x'$. المطلوب: Θ. الحل: الخطوة 1: $\rho = 1, \arccos(1) = 0$، $\Theta = \frac{\|x\|^2}{2} + \frac{\|x\|^2}{2\pi}\pi = \|x\|^2$. النتيجة: $\|x\|^2$. الربط بالذكاء الاصطناعي: يتّفق مع القطر.

مثال (7-2.40): متضادّان المعطيات: $x' = -x$. المطلوب: Θ (ReLU). الحل: الخطوة 1: $\rho = -1, \arccos(-1) = \pi$، $\Theta = -\frac{\|x\|^2}{2} + \frac{\|x\|^2}{2\pi}(\pi - \pi) = \frac{-\|x\|^2}{2}$. النتيجة: $-\|x\|^2/2$. الربط بالذكاء الاصطناعي: إشارة سالبة ممكنة.

مثال (8-2.40): أبعاد النواة المعطيات: n نقطة بيانات. المطلوب: بُعد Θ. الحل: الخطوة 1: متماثلة $n \times n$. النتيجة: $n \times n$. الربط بالذكاء الاصطناعي: تكبر مع البيانات لا المعاملات.

مثال (9-2.40): متماثلة القطرين المعطيات: هل Θ متماثلة؟ المطلوب: برهان سريع. الحل: الخطوة 1: الجداء الداخليّ متماثل $\Rightarrow \Theta(x,x') = \Theta(x',x)$. النتيجة: نعم. الربط بالذكاء الاصطناعي: شرط النواة الموجبة-شبه المحدّدة لاحقاً.

مثال (10-2.40): اعتمادها على θ المعطيات: شبكة عميقة حقيقية. المطلوب: هل Θ ثابتة؟ الحل: الخطوة 1: لعرض منتهٍ نعم تتغيّر؛ للانهائيّ تتجمّد عند $\Theta(0)$. النتيجة: تبقى عند العرض اللانهائيّ. الربط بالذكاء الاصطناعي: جوهر التحليل.

مثال (11-2.40): عصبون بانحياز المعطيات: $f = \theta^\top x + b$، ندمج b في θ كـ1. المطلوب: Θ. الحل: الخطوة 1: $\nabla_\theta f = [x;1]$؛ $\Theta = \langle [x;1],[x';1]\rangle = x^\top x' + 1$. النتيجة: $x^\top x' + 1$. الربط بالذكاء الاصطناعي: إضافة التقاطع.

مثال (12-2.40): نواة متعدّدة المخرجات المعطيات: $f \in \mathbb{R}^C$. المطلوب: شكل Θ. الحل: الخطوة 1: $\Theta \in \mathbb{R}^{C\times C}$ لكلّ زوج، أو نعامل المخرجات كمتّجه واحد $\Rightarrow$ أبعاد $Cn \times Cn$. النتيجة: موتر. الربط بالذكاء الاصطناعي: تصنيف متعدّد الفئات.

مثال (13-2.40): العلاقة مع الجاكوبيّ المعطيات: $J(x) = \nabla_\theta f(x)$ أبعادها $|\theta|$. المطلوب: $\Theta = JJ^\top$؟ الحل: الخطوة 1: $\langle J(x), J(x')\rangle = (J(x))^\top J(x')$ $\Rightarrow$ نعم للبيانات الفردية. النتيجة: $\Theta = JJ^\top$. الربط بالذكاء الاصطناعي: حساب عمليّ عبر الجاكوبيّ.

مثال (14-2.40): قابلية التفاضل المعطيات: هل Θ قابلة للاشتقاق؟ المطلوب: اشرح. الحل: الخطوة 1: f قابلة للتفاضل $\Rightarrow$ التدرّج والجداء قابلان $\Rightarrow \Theta$ قابلة. النتيجة: نعم. الربط بالذكاء الاصطناعي: أساس الاشتقاق في الديناميكا.

مثال (15-2.40): لماذا النواة لا خطّية؟ المعطيات: عصبون خطّي $\Rightarrow$ خطّية؛ ReLU $\Rightarrow$ لا. المطلوب: التفسير. الحل: الخطوة 1: التنشيط اللاخطّي (ReLU) يجعل Θ دالةً لا خطّية في x, x' (عبر $\arccos\rho$). النتيجة: قوة التعبير. الربط بالذكاء الاصطناعي: سبب تفوّق الشبكات.

أخطاء شائعة

- **الخلط بين $JJ^\top$ و$J^\top J$:** النواة $n \times n$ هي $J_{n\times p}J_{p\times n}^\top$ لا العكس.
- **نسيان أخذ التوقّع عند العرض اللانهائيّ:** Θ العشوائيّة يجب تثبيتها.
- **اعتبار Θ ثابتة دائماً:** فقط في النظام النوويّ (عرض لانهائيّ).
- **الخلط بين القطر والخارج:** القطر $x^\top x = $ لا يكفي لوصف الزوج.
- **ظنّ النواة خطّية دائماً:** ReLU تُنتج لا خطّية عبر arccos.

صياغة رسمية: بتدريب انحداريّ سلس (gradient flow) $\dot\theta = -\nabla_\theta L$، $L = \frac{1}{2}\sum_i (f(x_i) - y_i)^2$، فإنّ مخرجات بيانات التدريب تحقّق

$$\frac{d}{dt} f(x_i; t) = -\sum_j \Theta_{ij}(t)\,\big(f(x_j;t) - y_j\big) \tag{3.40}$$

حيث $\Theta_{ij}(t) = \langle \nabla_\theta f(x_i), \nabla_\theta f(x_j)\rangle$ مُقيَّمة عند $\theta(t)$.

جدول الرموز

الرمز	المعنى
$f(x_i;t)$	خرج نقطة i في زمن t
$\Theta(t)$	مصفوفة النواة في الزمن t
y_i	الهدف

الرسم

<figure> الشكل<figcaption> 2.40: الخطأ يتبع معادلة تفاضلية خطّيةً في النواة، عند تجمّدها تكون الانحدار الأسيّ مضموناً.</figcaption> </figure>

البرهان

الخطوة 1 (اشتقاق السلسلة): $\dot f_i = \langle \nabla_\theta f_i, \dot\theta\rangle = -\langle \nabla_\theta f_i, \sum_j (f_j - y_j)\nabla_\theta f_j\rangle$. ■

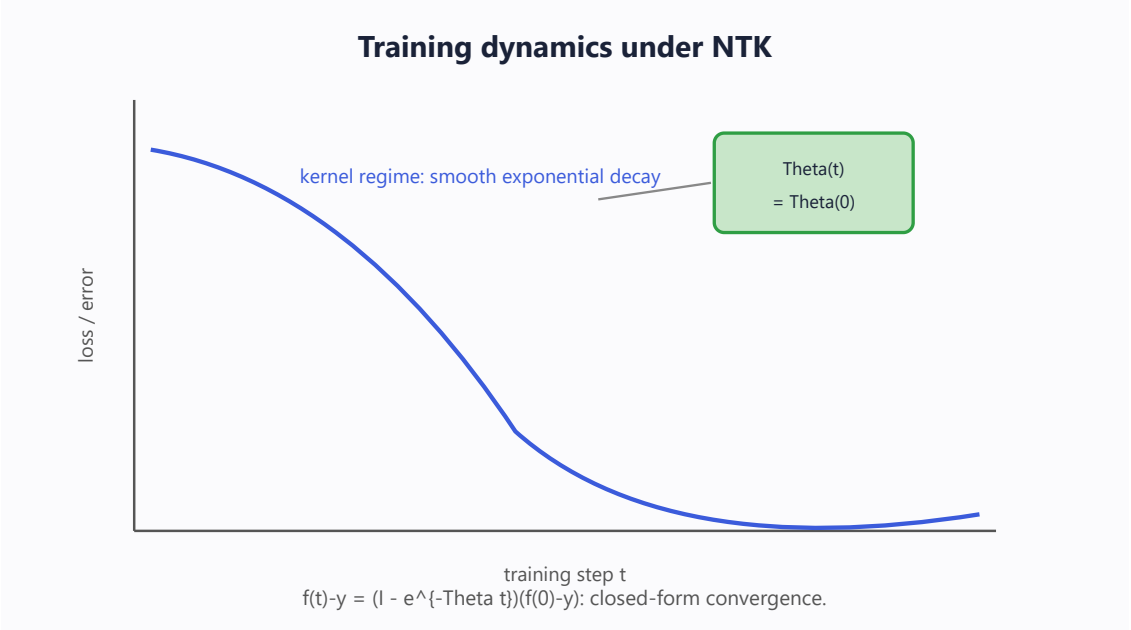
الخطوة 2 (صياغة النواة): المعامل الداخليّ $\Theta_{ij} \Rightarrow (3.40)$. ■

الخطوة 3 (صيغة المتّجه): بصيغة مصفوفة $\dot f = -\Theta(t)(f - y)$. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.40): حالة خطّية بسيطة المعطيات: $\Theta(t) = 3$ ثابت، نقطة واحدة $y = 1, f(0) = 0$. المطلوب: $f(t)$. الحل: الخطوة 1: $\dot f = -3(f - 1) \Rightarrow f(t) = 1 + e^{-3t}(0 - 1) = 1 - e^{-3t}$. النتيجة: $f(t) = 1 - e^{-3t}$. الربط بالذكاء الاصطناعي: تقارب أسيّ.

مثال (2-3.40): سرعة التقارب المعطيات: نفس (1-3.40)، $t = 1$. المطلوب: $f(1)$. الحل: الخطوة 1: $f(1) = 1 - e^{-3} \approx 1 - 0.0498 = 0.9502$. النتيجة: 0.9502. الربط بالذكاء الاصطناعي: قريب من الهدف.



شكل ٢٠٤٠: *
ديناميكا التدريب

مثال (3.40-3): مصفوفة 2×2 المعطيات: $\Theta = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$، $f(0) = [0,0]^\top, y = [1,1]^\top$. المطلوب: المعادلة. الحل: الخطوة 1: $\dot{f} = -\Theta(f-y) = -\Theta(f-[1,1])$. النتيجة: نظام مقترن. الربط بالذكاء الاصطناعي: النقاط تتأثّر ببعضها.

مثال (4-3.40): قيم ذاتية لـΘ أعلاه المعطيات: $\Theta = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$. المطلوب: $\lambda_{min}, \lambda_{max}$. الحل: الخطوة 1: قيمتها $2+1=3$ و$2-1=1 \Rightarrow \{3,1\}$. النتيجة: $1, 3$. الربط بالذكاء الاصطناعي: معدّل التقارب أقلّها.

مثال (5-3.40): اتجاه التقارب المعطيات: نفس Θ، $f(0) = [0,0], y = [1,1]$. المطلوب: الحلّ في الأساس الذاتيّ. الحل: الخطوة 1: y متّجه ذاتيّ لـ$\lambda = 3$؛ الحل $f(t) = [1-e^{-3t}, 1-e^{-3t}]$. النتيجة: تقارب متزامن. الربط بالذكاء الاصطناعي: الهدف متناظر.

مثال (6-3.40): هدف غير متناظر المعطيات: $y = [1,0]^\top$ مع نفس Θ. المطلوب: المكوّن البطيء. الحل: الخطوة 1: فكّ y على الأساس الذاتيّ؛ المكوّن الموافق $\lambda = 1$ يتقارب ببطء e^{-t}. النتيجة: تقارب أبطأ. الربط بالذكاء الاصطناعي: أصغر قيمة ذاتية تحدّد السرعة.

مثال (7-3.40): شرط التقارب المعطيات: Θ موجبة-محدّدة مُفرَضة. المطلوب: هل يتقارب؟ الحل: الخطوة 1: كلّ $\lambda > 0 \Rightarrow e^{-\lambda t} \to 0 \Rightarrow f \to y$. النتيجة: نعم. الربط بالذكاء الاصطناعي: محدّدية النواة ضرورية.

مثال (8-3.40): قيمة ذاتية صفرية المعطيات: $\lambda_{min} = 0$. المطلوب: التبعة. الحل: الخطوة 1: المكوّن الموافق لا يتغيّر $\Rightarrow$ لا تقارب كامل. النتيجة: ركود. الربط بالذكاء الاصطناعي: نواة مفردّة = عيوب.

مثال (9-3.40): تغيّر Θ مع الزمن المعطيات: شبكة عرض منتهٍ. المطلوب: هل (3.40) تكفي؟ الحل: الخطوة 1: نعم كمعادلة لحظية، لكن $\Theta(t)$ متغيّرة $\Rightarrow$ لا حلّ مغلق بسيط. النتيجة: تحتاج تجميداً. الربط بالذكاء الاصطناعي: لذلك نفترض العرض اللانهائيّ.

مثال (10-3.40): أبعاد المعادلة المعطيات: n نقطة. المطلوب: بُعد (3.40). الحل: الخطوة 1: $\dot{f} \in \mathbb{R}^n$، $\Theta \in \mathbb{R}^{n \times n}$. النتيجة: نظام n-أبعاد. الربط بالذكاء الاصطناعي: يتضخّم مع البيانات.

مثال (11-3.40): استقراء النواة المفردة المعطيات: $\Theta = I_n$، $y = [1, 0, \ldots, 0]$. المطلوب: $f_1(t)$. الحل: الخطوة 1: $f_1(t) = 1 - e^{-t} \Rightarrow \dot{f}_1 = -(f_1 - 1)$. النتيجة: تقارب مستقل لكل نقطة. الربط بالذكاء الاصطناعي: نواة الهويّة = لا ارتباط.

مثال (12-3.40): معدّل الخطأ الكليّ المعطيات: $L = \frac{1}{2}\|f - y\|^2$، Θ موجبة. المطلوب: سلوك $L(t)$. الحل: الخطوة 1: $L(t) = \frac{1}{2}e^{-2\lambda_{min} t}\|f(0) - y\|^2$ تقريباً. النتيجة: هبوط أسيّ. الربط بالذكاء الاصطناعي: منحنى خسارة ناعم.

مثال (13-3.40): ماذا لو Θ غير متماثلة؟ المعطيات: في الممارسة $\Theta = \Theta^\top$. المطلوب: لماذا؟ الحل: الخطوة 1: الجداء الداخليّ متماثل $\Rightarrow$ النواة متماثلة القطرين. النتيجة: مضمونة. الربط بالذكاء الاصطناعي: شرط النواة.

مثال (14-3.40): التحقّق العدديّ المعطيات: $\Theta = [[2, 1], [1, 2]], f(0) = [0, 0], y = [1, 1], t = 0.5$. المطلوب: $f(0.5)$ تقريباً. الحل: الخطوة 1: الحل $1 - e^{-3 \cdot 0.5} = 1 - e^{-1.5} \approx 1 - 0.223 = 0.777$ (للمكوّن $\lambda = 3$). النتيجة: $[0.777, 0.777]$. الربط بالذكاء الاصطناعي: تحقّق من الصيغة.

مثال (15-3.40): العلاقة مع GD بخطوة المعطيات: نستخدم تدرّجاً منفصلاً. المطلوب: هل تبقى (3.40)؟ الحل: الخطوة 1: بخطوة صغيرة η تقارب $f \leftarrow f - \eta\Theta(f - y) \approx$ التدفّق المستمرّ. النتيجة: نعم تقريباً. الربط بالذكاء الاصطناعي: GD تقريب flow gradient.

أخطاء شائعة

- **الخلط في إشارة المعادلة:** $\dot{f} = -\Theta(f - y)$ لا $+\Theta(f - y)$.
- **نسيان أن Θ قد تتغيّر:** الحلّ المغلق يحتاج تجميدها.
- **ظنّ التقارب دائماً:** يتطلّب موجبة-محدّدة.
- **الخلط بين $\Theta(t)$ والجاكوبيّ:** النواة جداء الجاكوبيّات.
- **إهمال دور λ_{min}:** تحدّد سرعة التقارب.

صياغة رسمية: بتوسيع العرض $m \to \infty$ (عدد الوحدات أو المرشّحات)، تتجمّد نواة التماس عند قيمتها الابتدائية،

$$\Theta(t; \theta(t)) \xrightarrow[m \to \infty]{} \Theta(0) \equiv \mathbb{E}_{\theta(0)}\big[\Theta(\theta(0))\big] \tag{4.40}$$

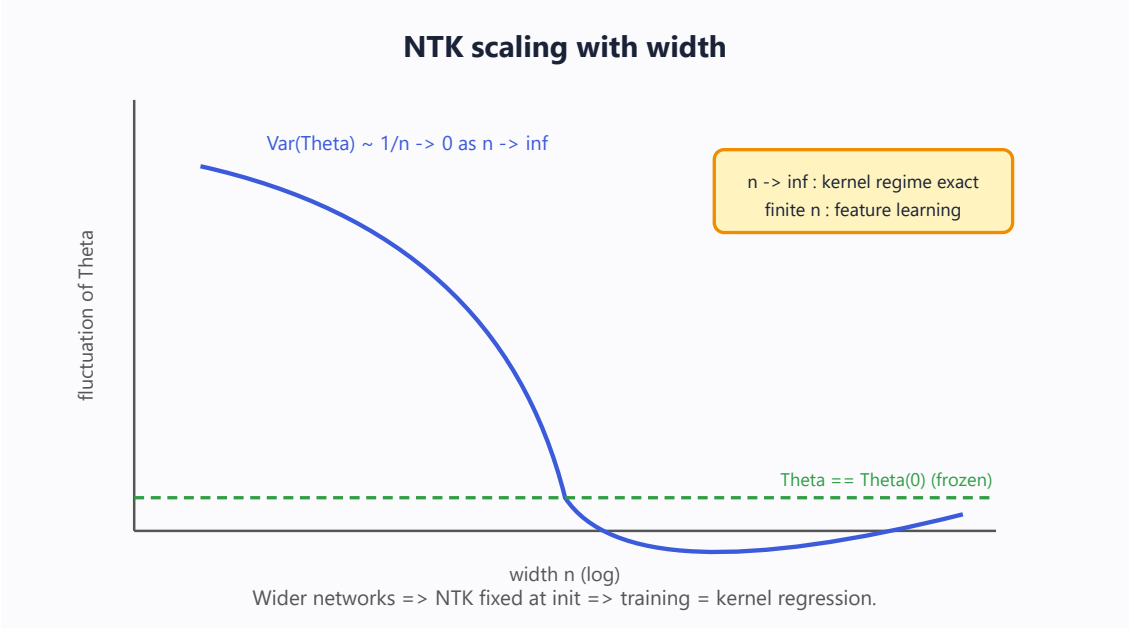
حيث التقارب حتميّ (deterministic) لمعيار التدريب القياسيّ.

جدول الرموز

الرمز	المعنى
m	عرض الشبكة (عدد الوحدات)
$\Theta(0)$	النواة عند التهيئة
نظام التدريب الكسول	الميزات لا تتحرّك

الرسم

<figure>الشكل 5.40: مع توسّع العرض m تتقلّص تذبذبات $\Theta(t)$ حول $\Theta(0)$ بمعدّل $1/\sqrt{m}$.</figure>



شكل ٣٠.٤٠: *
توسّع العرض

البرهان

الخطوة 1 (القانون المركزيّ الحدّيّ): عند $m \to \infty$ تتقارب التنشيطات قبل-الخطّية إلى غوسيّة، تغيير الخرج من تحديث معامل واحد هو $O(1/\sqrt{m})$. ■

الخطوة 2 (تركّز النواة): Θ تعتمد على لحظات من الدرجة الثانية لتدرّجات المعاملات، وهي تتركّز حول حدّها اللانهائيّ بتباين $O(1/m)$. ■

الخطوة 3 (الثبات الزمنيّ): بما أنّ تحديث θ هو $O(1/\sqrt{m})$ لكلّ خطوة، تبقى $\Theta(t)$ ضمن $O(1/m)$ من $\Theta(0)$ لكلّ $t \Rightarrow$ عمليّاً ثابتة. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.40): عصبون خطّيّ بلا انحياز المعطيات: $f(x;\theta) = \theta^\top x$. المطلوب: هل Θ تتجمّد؟ الحل: الخطوة 1: $\nabla_\theta f = x$ لا يعتمد $\theta \Rightarrow \Theta = x^\top x'$ ثابتة لأيّ m. النتيجة: نعم (حالة تافهة). الربط بالذكاء الاصطناعي: الأساس الخطّيّ.

مثال (2-4.40): تقدير تذبذب النواة المعطيات: تباين $\Theta(t)$ حول $\Theta(0)$ هو $\sigma_\Theta^2 \approx C/m$، $C = 1$. المطلوب: σ_Θ لـ $m = 10^4$. الحل: الخطوة 1: $1/\sqrt{10^4} = 1/100 = 0.01$. النتيجة: 1٪. الربط بالذكاء الاصطناعي: عرض كبير $\Rightarrow$ استقرار.

مثال (3-4.40): نفس التباين لـ $m = 10^6$ المعطيات: $m = 10^6$. المطلوب: σ_Θ. الحل: الخطوة 1: $1/\sqrt{10^6} = 0.001$. النتيجة: 0.1٪. الربط بالذكاء الاصطناعي: تجميد شبه تامّ.

مثال (4-4.40): حدّ هويفدنغ للتركّز المعطيات: لكلّ زوج، $\Theta_{ij} \in [0,1]$ مستقلّ عبر المعاملات، $P(|\Theta(t) - \Theta(0)| > \varepsilon) \le 2\exp(-m\varepsilon^2/2)$. المطلوب: الحدّ لـ $m = 10^6, \varepsilon = 0.01$. الحل: الخطوة 1: $\exp(-10^6 \cdot 10^{-4}/2) = \exp(-50) \approx 1.9 \times 10^{-22}$. الخطوة 2: الحدّ $= 3.8 \times 10^{-22} \le$. النتيجة: ضئيل جدّاً. الربط بالذكاء الاصطناعي: ضمان حتميّ عمليّ.

مثال (5-4.40): عرض صغير $m = 100$ المعطيات: $m = 100$. المطلوب: σ_Θ. الحل: الخطوة 1: $= 1/\sqrt{100}$ 0.1. النتيجة: 10٪ (تذبذب كبير). الربط بالذكاء الاصطناعي: هنا تظهر ميزات متحرّكة.

مثال (6-4.40): تأثير التجميد على المعادلة المعطيات: بـ Θ ثابتة نحصل (5.40)؛ بـ Θ متغيّرة لا. المطلوب: عدّد النتيجة. الحل: الخطوة 1: التجميد يحوّل المعادلة التفاضليّة إلى نظام خطّيّ قابل للحلّ المغلق. النتيجة: شرط ضروري للحلّ المغلق. الربط بالذكاء الاصطناعي: جسر إلى (5.40).

مثال (7-4.40): قياس عمليّ للتركّز المعطيات: نهيّئ شبكة عرض m مرّتين $K = 100$ مرّة ونحسب $\Theta(0)$ لزوج ثابت. المطلوب: كيف يتغيّر الانحراف المعياريّ؟ الحل: الخطوة 1: $s_m \propto 1/\sqrt{m}$؛ من $m = 10^2$ إلى 10^4 يخفض $10\times$. النتيجة: انخفاض بمقدار عشرة. الربط بالذكاء الاصطناعي: تجربة قابلة للتنفيذ.

مثال (8-4.40): نظام التدريب الكسول المعطيات: مقياس $\|\phi(x;\theta(t)) - \phi(x;\theta(0))\|$. المطلوب: سلوكه عند $m \to \infty$. الحل: الخطوة 1: النواة مجمّدة $\Rightarrow$ الخطّيّة حول $\theta(0)$ صالحة $\Rightarrow$ الميزات لا تتحرّك. النتيجة: تدريب كسول. الربط بالذكاء الاصطناعي: سبب محدوديّة NTK.

مثال (9-4.40): معدّل تقارب النواة المعطيات: $|\Theta(t) - \Theta(0)| \le \frac{M}{\sqrt{m}}$ لثابت M. المطلوب: القيمة لـ $M = 2, m = 400$. الحل: الخطوة 1: $2/\sqrt{400} = 2/20 = 0.1$. النتيجة: 10.0. الربط بالذكاء الاصطناعي: ربط العرض بالخطأ.

مثال (10-4.40): مقارنة زمنيّة المعطيات: $m_1 = 10^3, m_2 = 10^5$. المطلوب: نسبة التذبذبات. الحل: الخطوة 1: $\sigma_1/\sigma_2 = \sqrt{10^5/10^3} = \sqrt{100} = 10$. النتيجة: الأصغر عرضاً أكثر اضطراباً بـ$10\times$. الربط بالذكاء الاصطناعي: موازنة الحساب والدقّة.

مثال (11-4.40): متى يفشل التجميد؟ المعطيات: شبكة عميقة جدّاً أو m صغير جدّاً. المطلوب: اشرح. الحل: الخطوة 1: العمق الكبير يضخّم تراكم $O(1/\sqrt{m})$ عبر الطبقات $\Rightarrow$ قد تُهمَل التقريبات. النتيجة: التجميد ليس مضموناً دائماً. الربط بالذكاء الاصطناعي: حدود التحليل.

مثال (12-4.40): العلاقة مع التهيئة المعطيات: $\Theta(0) = \mathbb{E}_{\theta(0)}[\Theta(\theta(0))]$. المطلوب: هل تُحسب تحليليّاً؟ الحل: الخطوة 1: نعم لشبكات ReLU/erf عبر تكاملات زاوية معروفة (مثل 4-2.40). النتيجة: حساب مغلق. الربط بالذكاء الاصطناعي: أساس مكتبات NTK.

مثال (13-4.40): تقدير زمن الوصول للتجميد المعطيات: نريد $\sigma_\Theta < 0.05$. المطلوب: أدنى m. الحل: الخطوة 1: $1/\sqrt{m} < 0.05 \Rightarrow \sqrt{m} > 20 \Rightarrow m > 400$. النتيجة: $m \ge 400$ تقريباً. الربط بالذكاء الاصطناعي: اختيار العرض.

مثال (14-4.40): الفرق عن التعلّم الميزاتيّ المعطيات: في نظام النواة Θ ثابتة؛ في تعلّم الميزات Θ متطوّرة. المطلوب: أين نحن عمليّاً؟ الحل: الخطوة 1: عروض 10^3–10^4 غالباً بين النظامين؛ العروض 10^5 $<$ أقرب للنواة. النتيجة: منطقة انتقاليّة. الربط بالذكاء الاصطناعي: يُغطّى في (8.40).

مثال (15-4.40): خلاصة عددية المعطيات: خذ $\Theta(0) = 2$، عرض m يزداد. المطلوب: ما قيمة $\Theta(t)$ المُتوقّعة عند t كبير؟ الحل: الخطوة 1: بغضّ النظر عن t، $\Theta(t) \approx \Theta(0) = 2$ ضمن $O(1/\sqrt{m})$. النتيجة: 2. الربط بالذكاء الاصطناعي: ثبات النواة = ثبات الديناميكا.

أخطاء شائعة

- **الظنّ أن التجميد يحصل لأيّ عرض:** فقط عند $m \to \infty$ حتميّاً؛ العروض الصغيرة تتذبذب.
- **الخلط بين "النواة ثابتة" و"الميزات ثابتة":** النواة ثابتة تعني الخطّيّة حول التهيئة (كسول) لا غياب التعلّم.
- **إهمال معدّل $1/\sqrt{m}$:** التذبذب يتلاشى ببطء؛ $m = 100$ قد لا تكفي.

- **توقّع تجميد في شبكات عميقة جدّاً:** التراكم عبر الطبقات قد يُفسد التقريب.
- **الخلط مع SGD:** التجميد يخصّ flow gradient بخطوة صغيرة لا SGD الخشنة دائماً.

صياغة رسمية: بتجميد $\Theta(t) = \Theta(0)$، تنحلّ معادلة التدريب $\dot{f} = -\Theta(0)(f - y)$ مغلقاً:

$$f(t) - y = e^{-\Theta(0)\,t}\,\big(f(0) - y\big) \tag{5.40}$$

وبالتالي $f(t) = y + e^{-\Theta(0)t}(f(0) - y)$. الخطأ $e(t) = f(t) - y$ يتلاشى أسيّاً:

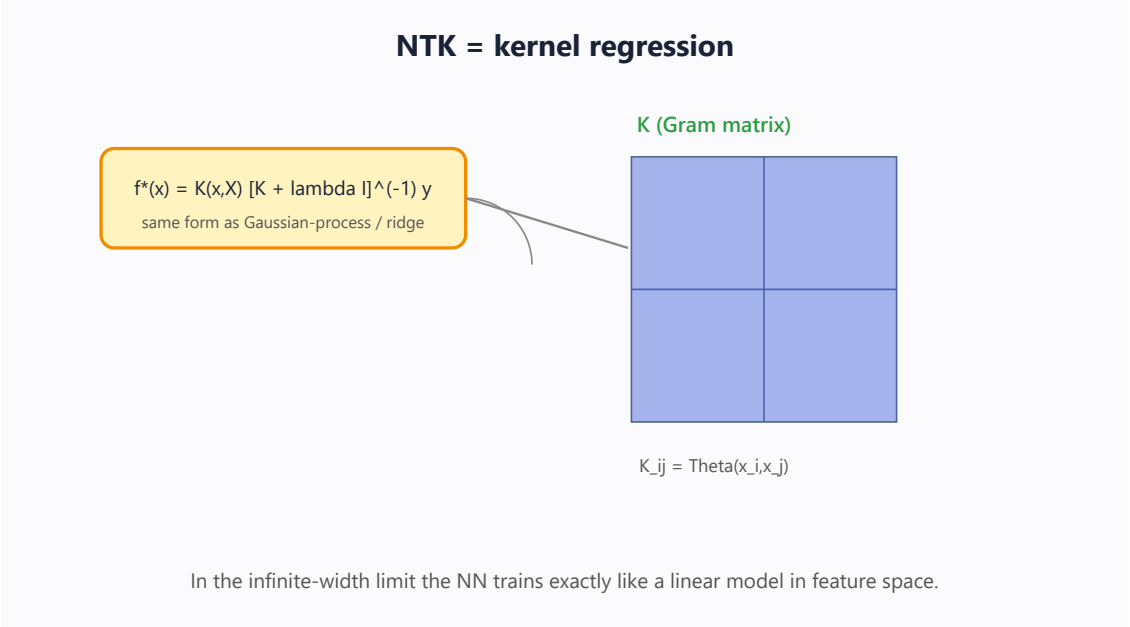
$$\|e(t)\| \le e^{-\lambda_{\min}(\Theta(0))\,t}\,\|e(0)\| \tag{6.40}$$

جدول الرموز

الرمز	المعنى
$e(t) = f(t) - y$	خطأ التدريب
$\lambda_{\min}$	أصغر قيمة ذاتية لـ$\Theta(0)$
$e^{-\Theta t}$	كسر المصفوفة الأسّ

الرسم

<figure> الشكل<figcaption> 3.40: الحلّ المغلق يحوّل التدريب إلى انحدار نوويّ؛ الخطأ يهبط أسيّاً بمعدّل



شكل ٤٠.٤٠: *
انحدار النواة

</figure> .</figcaption>$\lambda_{\min}$

البرهان

الخطوة 1 (الأساس الذاتيّ): أنطرح $\Theta(0) = Q\Lambda Q^\top$؛ في هذا الأساس $\dot{e}_i = -\lambda_i e_i$. ■

الخطوة 2 (التكامل): $e(t) = Qe^{-\Lambda t}Q^\top e(0) = e^{-\Theta(0)t}e(0) \Rightarrow e_i(t) = e^{-\lambda_i t}e_i(0)$. ■

الخطوة 3 (التقارب): لو $\lambda_{\min} > 0$ فإنّ $e^{-\lambda_{\min}t} \to 0 \Rightarrow f(t) \to y$؛ المعدّل أبطأ قيمة ذاتية. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.40): حالة القيمة المفردة المعطيات: $\Theta(0) = 3$، $f(0) = 0, y = 1$. المطلوب: $f(t)$. الحل: الخطوة 1: $f(t) = 1 + e^{-3t}(0 - 1) = 1 - e^{-3t}$. النتيجة: $f(t) = 1 - e^{-3t}$. الربط بالذكاء الاصطناعي: تقارب أسيّ قياسيّ.

مثال (2-5.40): الخطأ الابتدائيّ المعطيات: نفس (1-5.40). المطلوب: $e(t)$. الحل: الخطوة 1: $e(t) = f(t) - y = -e^{-3t}$. النتيجة: $|e(0)| = 1$. الربط بالذكاء الاصطناعي: الاتساق مع المعادلة.

مثال (3-5.40): زمن للخطأ 0.01 المعطيات: $e^{-3t} = 0.01$. المطلوب: t. الحل: الخطوة 1: $3t = \ln 100 = 4.605 \Rightarrow t = 1.535$. النتيجة: $t \approx 1.535$. الربط بالذكاء الاصطناعي: تقدير زمن التدريب.

مثال (4-5.40): الكسر المتبقّي المعطيات: $\lambda = 3, t = 1$. المطلوب: النسبة المتبقّية e^{-3}. الحل: الخطوة 1: $e^{-3} \approx 0.0498$. النتيجة: 4.98٪. الربط بالذكاء الاصطناعي: تقارب ~95٪.

مثال (5-5.40): زمن لـ95٪ المعطيات: نريد $e^{-\lambda t} = 0.05$. المطلوب: t بـ $\lambda = 3$. الحل: الخطوة 1: $t = \ln(20)/3 = 2.996/3 = 0.999$. النتيجة: $t \approx 1.0$. الربط بالذكاء الاصطناعي: نقطة توقّف شائعة.

مثال (6-5.40): القيمة الذاتية البطيئة المعطيات: $\Theta(0) = \mathrm{diag}(3, 1)$، $f(0) = [0, 0], y = [1, 1]$. المطلوب: $f_2(1)$. الحل: الخطوة 1: $e_2(t) = e^{-1 \cdot 1}e_2(0) = e^{-1}(-1) \approx -0.368 \Rightarrow f_2(1) = 1 - e^{-1} \approx 0.632$. النتيجة: $f_2(1) \approx 0.632$. الربط بالذكاء الاصطناعي: $\lambda_{\min}$ يبطئ التقارب.

مثال (7-5.40): زمن طويل $t = 2$ المعطيات: $\lambda = 3$. المطلوب: الكسر. الحل: الخطوة 1: $e^{-6} \approx 0.00248$. النتيجة: 0.25٪. الربط بالذكاء الاصطناعي: تقارب شبه كامل.

مثال (8-5.40): معدّل عامّ المعطيات: الكسر المتبقّي $e^{-\lambda t} =$. المطلوب: t لجعله 0.001 بـ $\lambda = 2$. الحل: الخطوة 1: $2t = \ln 1000 = 6.908 \Rightarrow t = 3.454$. النتيجة: $t \approx 3.45$. الربط بالذكاء الاصطناعي: حساسيّة للمعدّل.

مثال (9-5.40): قيمة ذاتية سالبة المعطيات: $\lambda_{\min} < 0$ (نواة غير موجبة). المطلوب: سلوك $e(t)$. الحل: الخطوة 1: $e^{-\lambda t} = e^{|\lambda| t} \to \infty \Rightarrow$ ينفجر الخطأ. النتيجة: لا تقارب. الربط بالذكاء الاصطناعي: ضرورة الموجبة-شبه المحدّدة.

مثال (10-5.40): قيمة ذاتية صفرية المعطيات: $\lambda = 0$ لمكوّن. المطلوب: ذلك المكوّن. الحل: الخطوة 1: $e_i(t) = e_i(0) \Rightarrow e^{-0 \cdot t} = 1$ ثابت. النتيجة: ركود دائم. الربط بالذكاء الاصطناعي: نواة مفردّة.

مثال (11-5.40): $\lambda = 0.1$ بطيء المعطيات: $\lambda = 0.1$. المطلوب: t لـ95٪. الحل: الخطوة 1: $t = \ln 20/0.1 = 2.996/0.1 = 29.96$. النتيجة: $t \approx 30$. الربط بالذكاء الاصطناعي: تدريب بطيء جدّاً.

مثال (12-5.40): $\lambda = 10$ سريع المعطيات: $\lambda = 10$. المطلوب: t لـ95٪. الحل: الخطوة 1: $t = \ln 20/10 = 0.2996$. النتيجة: $t \approx 0.30$. الربط بالذكاء الاصطناعي: تقارب سريع.

مثال (13-5.40): التعميم على مصفوفة المعطيات: $\Theta(0) = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$، $f(0) = [0, 0], y = [1, 1]$. المطلوب: $f_1(t)$. الحل: الخطوة 1: y متّجه ذاتيّ لـ$\lambda = 3 \Rightarrow f_1(t) = 1 - e^{-3t}$. النتيجة: $1 - e^{-3t}$ لكليهما. الربط بالذكاء الاصطناعي: يطابق (3-5.40).

مثال (14-5.40): الخطأ الكليّ المعطيات: $L(t) = \frac{1}{2}\|e(t)\|^2$. المطلوب: سلوك L. الحل: الخطوة 1: $L(t) = \frac{1}{2}e^{-2\lambda_{\min}t}\|e(0)\|^2$ تقريباً. النتيجة: هبوط أسيّ مزدوج السرعة. الربط بالذكاء الاصطناعي: منحنى خسارة.

مثال (15-5.40): التنبّؤ بنقطة جديدة المعطيات: بعد التدريب الكامل، للاختبار $f_{test} = \mathcal{K}_{test,train}\Theta_{train}^{-1}y$. المطلوب: اشرح لماذا. الحل: الخطوة 1: عند $t \to \infty$ الحلّ يمرّ بكلّ نقاط التدريب $\Rightarrow$ تنبّؤ النواة القياسيّ. النتيجة: interpolation. الربط بالذكاء الاصطناعي: ربط NTK بالانحدار النوويّ.

أخطاء شائعة

- **قلب إشارة الأسّ:** $f(t)-y=e^{-\Theta t}(f(0)-y)$ لا $(I-e^{-\Theta t})(f(0)-y)$ (هذه الأخيرة تعطي $f(0)-f(t)$).
- **نسيان شرط** $\lambda_{\min}>0$: بلا موجبة-شبه محدّدة لا تقارب.
- **الخلط بين** $e^{-\Theta t}$ **والأسّ القياسيّ:** هي كسر مصفوفة $Qe^{-\Lambda t}Q^\top$.
- **توقّع انطباق SGD خشن:** الحلّ المغلق لـ flow gradient بخطوة صغيرة.
- **إهمال المكوّن البطيء:** $\lambda_{\min}$ يحدّد الزمن الفعليّ.

صياغة رسمية: عند التهيئة، مخرجات الشبكة تتوزّع كعملية غوسيّة (NNGP) بنواة أوليّة $\mathcal{G}(x,x')=\mathbb{E}_\theta[f(x)f(x')]$. للشبكة ذات الطبقة الأخيرة الخطّية $f=W_L\phi_{L-1}$، تحقّق نواة NTK

$$\Theta(x,x')=\mathcal{G}(x,x')+\dot{\mathcal{G}}(x,x') \tag{7.40}$$

حيث $\mathcal{G}$ مساهمة معاملات الطبقة الأخيرة (انحدار النواة) و$\dot{\mathcal{G}}$ مساهمة الطبقات المخفيّة (تعلّم الميزات). كلتاهما تتبع نفس تكرار التغاير عبر الطبقات.

جدول الرموز

الرمز	المعنى
$\mathcal{G}$	نواة NNGP (الأوليّة)
$\dot{\mathcal{G}}$	مشتقّة النواة بالنسبة لمعاملات الطبقة
W_L	أوزان الطبقة الأخيرة

الرسم

<figure> الشكل<figcaption> 4.40: NNGP تصف التوزيع الأوليّ (النقاط الرمادية)؛ NTK تصف تطوّره (السهم) فوق نفس التكرار.</figcaption> </figure>

البرهان

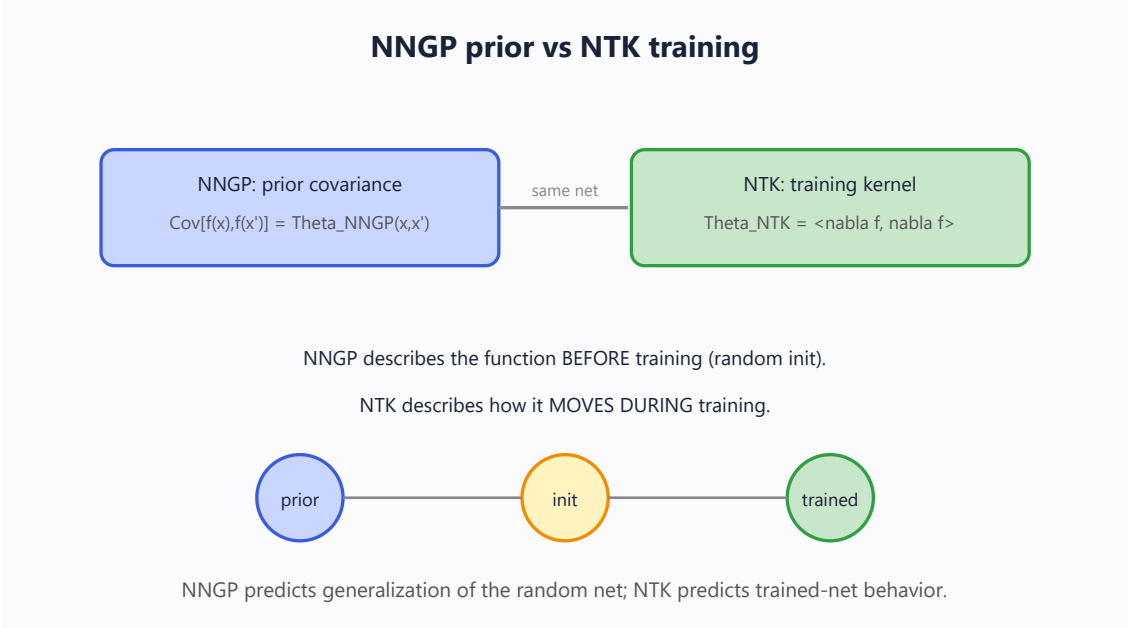
الخطوة 1 (أوليّة :(NNGP بتهيئة غوسيّة، $f(x)$ عند نقاط منتهية هو متّجه غوسيّ بغلاف $\mathcal{G}$. ■

الخطوة 2 (تفكيك :(NTK $\Theta=\langle\nabla_W f,\nabla_W f\rangle+\sum_l\langle\nabla_{W_l}\phi,\dots\rangle=\mathcal{G}+\dot{\mathcal{G}}$؛ الحدّ الأول من W_L والثاني من الطبقات غير الخطّيّة. ■

الخطوة 3 (نفس التكرار): كلّ من $\mathcal{G},\dot{\mathcal{G}}$ يُبنى من نفس $\Sigma^{(l)}$ لتغاير التنشيطات $\Rightarrow$ حسابهما معاً فعّال. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.40): شبكة خطّيّة صرفة المعطيات: $f=Wx$، $W\sim\mathcal{N}(0,I)$. المطلوب: $\mathcal{G}$ وΘ. الحل: الخطوة 1: $\mathcal{G}=\mathbb{E}[Wx(Wx')^\top]=xx'$؛ $\Theta=xx'$ أيضاً (لا طبقات مخفيّة). النتيجة: $\mathcal{G}=\Theta=xx'$. الربط بالذكاء الاصطناعي: لا فرق في الشبكة الخطّيّة.



شكل ٥.٤٠: *
NNGP مقابل NTK

مثال (2-6.40): عرض لانهائيّ طبقتين المعطيات: $\mathcal{G}(x,x')$ بصيغة (4-2.40) لـReLU. المطلوب: هل $\Theta = \mathcal{G}$؟ الحل: الخطوة 1: لا، $\Theta = \mathcal{G} + \dot{\mathcal{G}}$ والحدّ $\dot{\mathcal{G}}$ من مشتقّة ReLU يضيف $\frac{\|x\|\|x'\|}{2\pi}(\pi - \arccos\rho)$. النتيجة: $\Theta > \mathcal{G}$. الربط بالذكاء الاصطناعي: NTK تتجاوز NNGP.

مثال (3-6.40): حساب عدديّ المعطيات: $x = [1,0], x' = [1,1]/\sqrt{2}$ (كـ5-2.40). المطلوب: $\mathcal{G}$ وΘ. الحل: الخطوة 1: $\mathcal{G} = 0.7286$ (من 5-2.40)؛ $\dot{\mathcal{G}} = \frac{\|x\|\|x'\|}{2\pi}(\pi - \arccos\rho) = 0.375 \Rightarrow \Theta = 0.7286 + 0.375 = 1.1036$. النتيجة: $\mathcal{G} = 0.7286, \Theta = 1.1036$. الربط بالذكاء الاصطناعي: NTK أكبر من NNGP.

مثال (4-6.40): توقّع NNGP المعطيات: $\hat{y}_* = \mathcal{G}_{*,\text{train}}\mathcal{G}_{\text{train}}^{-1}y$. المطلوب: اشرح. الحل: الخطوة 1: هذا متوسّط العملية الغوسيّة الشرطيّة $\Rightarrow$ تنبؤ بايزيّ. النتيجة: لا يتدرّب (أوليّ فقط). الربط بالذكاء الاصطناعي: NNGP = NTK + تطوّر.

مثال (5-6.40): تنبّؤ NTK المعطيات: $\hat{y}_*^{NTK} = \Theta_{*,\text{train}}\Theta_{\text{train}}^{-1}y$. المطلوب: الفرق. الحل: الخطوة 1: يمرّ بنقاط التدريب (interpolation) بينما NNGP لا. النتيجة: NTK تسرّب البيانات بالكامل. الربط بالذكاء الاصطناعي: سبب تجاوز NNGP.

مثال (6-6.40): نقطة واحدة المعطيات: $\mathcal{G} = 2, \Theta = 3, y = 1$. المطلوب: تنبّؤ NNGP وNTK لنقطة بنفسها. الحل: الخطوة 1: NNGP: $1 \cdot 1 = 1$؛ NTK: $1 \cdot 3/3 = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: على بيانات التدريب يتساويان.

مثال (7-6.40): نقطة اختبار مختلفة المعطيات: $\mathcal{G}_{*t} = 1.5, \mathcal{G}_{tt} = 2, \Theta_{*t} = 2.5, \Theta_{tt} = 3, y = 1$. المطلوب: التوقّعان. الحل: الخطوة 1: NNGP: $0.75 = 1.5/2$؛ NTK: $0.833 = 2.5/3$. النتيجة: 0.75 مقابل 0.833. الربط بالذكاء الاصطناعي: NTK أقرب للهدف.

مثال (8-6.40): مساهمة الطبقة الأخيرة المعطيات: $\Theta = 5$، الحدّ من W_L هو 3. المطلوب: $\dot{\mathcal{G}}$. الحل: الخطوة 1: $\dot{\mathcal{G}} = \Theta - \mathcal{G} = 5 - 3 = 2$. النتيجة: 2. الربط بالذكاء الاصطناعي: فصل الميزات.

مثال (9-6.40): تكرار التغاير (طبقة واحدة) المعطيات: $\Sigma_{xx'} = \frac{1}{m}\sum_r \phi(w_r^\top x)\phi(w_r^\top x')$. المطلوب: حدّ $m \to \infty$. الحل: الخطوة 1: $\mathbb{E}_w[\phi(w^\top x)\phi(w^\top x')] \to$ تكامل مغلق لـReLU. النتيجة: صيغة (4-2.40). الربط بالذكاء الاصطناعي: حلقة الوصل.

مثال (40.6-10): عمق أكبر المعطيات: شبكة L طبقات. المطلوب: صيغة Θ العامّة. الحل: الخطوة 1: $\Theta = \sum_{l=1}^{L} \left(\prod_{r>l} \Sigma^{(r)}\right) \dot{\Sigma}^{(l)} \left(\prod_{r'<l} \Sigma^{(r')}\right)$. النتيجة: مجموع مساهمات الطبقات. الربط بالذكاء الاصطناعي: تفكيك العمق.

مثال (40.6-11): متى $\Theta \approx \mathcal{G}$؟ المعطيات: إذا كانت الطبقة الأخيرة فقط تتدرّب. المطلوب: اشرح. الحل: الخطوة 1: حينها $\dot{\mathcal{G}} \to 0 \Rightarrow \Theta = \mathcal{G}$. النتيجة: انحدار نوويّ صرف. الربط بالذكاء الاصطناعي: التدريب الكسول المحض.

مثال (40.6-12): عدم يقين NNGP المعطيات: تباينُ NNGP $\sigma_*^2 = \mathcal{G}_{**} - \mathcal{G}_{*t}\mathcal{G}_{tt}^{-1}\mathcal{G}_{t*}$. المطلوب: اشرح. الحل: الخطوة 1: هذا تباينُ التنبّؤ الغوسيّ $\Rightarrow$ قياس ثقة. النتيجة: NTK لا يملكه (يقين كامل). الربط بالذكاء الاصطناعي: ميزة بايزيّة.

مثال (40.6-13): مثال عدديّ للتباينُ المعطيات: $\mathcal{G}_{**} = 2, \mathcal{G}_{*t}\mathcal{G}_{tt}^{-1}\mathcal{G}_{t*} = 1.5$. المطلوب: σ_*^2. الحل: الخطوة 1: $2 - 1.5 = 0.5$. النتيجة: 0.5. الربط بالذكاء الاصطناعي: قياس عدم اليقين.

مثال (40.6-14): العلاقة مع NTK التدريبيّ المعطيات: بعد تدريب NTK كامل. المطلوب: هل يبقى Θ؟ الحل: الخطوة 1: نعم؛ النظام النوويّ يثبّت $\Theta = \Theta(0)$ طوال التدريب. النتيجة: نعم. الربط بالذكاء الاصطناعي: ربط بـ(40.4).

مثال (40.6-15): خلاصة المعطيات: $\mathcal{G} = 1, \dot{\mathcal{G}} = 0.5$. المطلوب: Θ. الحل: الخطوة 1: $\Theta = 1 + 0.5 = 1.5$. النتيجة: 1.5. الربط بالذكاء الاصطناعي: NTK = أوليّة + تطوّر.

أخطاء شائعة

- **الظنّ أن NNGP وNTK متطابقان:** NTK تضيف $\dot{\mathcal{G}}$ من تعلّم الميزات.
- **الخلط بين التوزيع الأوليّ والتطوّر:** NNGP = ما قبل التدريب؛ NTK = أثناء التدريب.
- **نسيان أن NNGP لا تتدرّب بالبيانات:** تنبّؤها لا يمرّ بنقاط التدريب.
- **الخلط بين $\mathcal{G}$ وΘ في التنبّؤ:** النواة الخاطئة تعطي نتائج مختلفة.
- **إهمال التباينُ:** NNGP توفّر ثقة لا يملكها NTK.

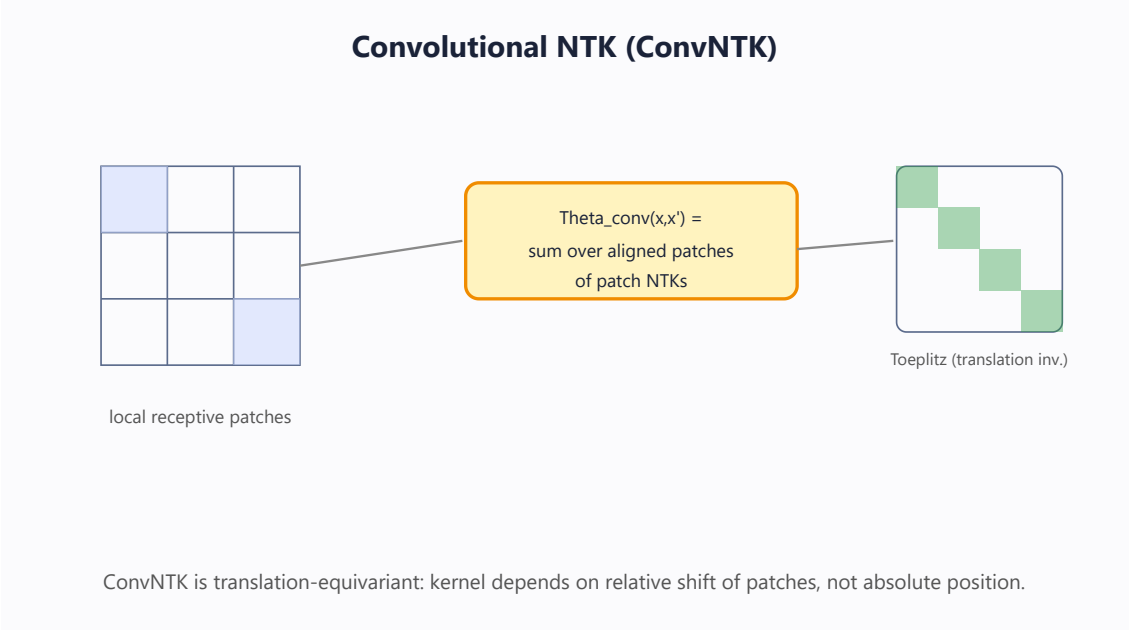
صياغة رسمية: لشبكة التفافية (CNN) بنواة التماس Θ_{conv}، تورث النواة تقارب الترجمة: لكلّ إزاحة g،

$$\Theta_{conv}(T_g x,\ T_g x') = \Theta_{conv}(x, x') \tag{40.8}$$

أي أنّ نواة التماس الالتفافيّة ثابتة تحت الترجمة (translation equivariant). وتبقى معادلة التدريب (kernel) $\dot{f} = -\Theta_{conv}(f - y)$ صالحةً بعمليات التفاف.

جدول الرموز

الرمز	المعنى
T_g	عملية ترجمة بإزاحة g
Θ_{conv}	نواة التماس الالتفافيّة
$*$	عملية الالتفاف



شكل ٦.٤٠: *
النواة الالتفافية

الرسم

<figure> الشكل<figcaption>6.40: ConvNTK تربط كلّ بكسل بجيرانه عبر الالتفاف؛ تقارب الترجمة يظهر بتكرار النمط.</figcaption> </figure>

البرهان

الخطوة 1 (تدرّج التفافيّ): معاملات الطبقات الالتفافية تُعلَّم عبر $\nabla_\theta f$ الذي يُحسب بعمليات التفاف (backprop مكانيّ). ■

الخطوة 2 (تقارب الترجمة): التفاف f ثمّ ترجمته = ترجمة f ثمّ التفافها؛ لذا الجاكوبيّات تتطابق تحت $T_g \Rightarrow \Theta$ ثابتة. ■

الخطوة 3 (الديناميكا): بما أنّ Θ_{conv} مبنية من التفاف، فمعادلة $\dot{f}$ تبقى محليّة مكانيّاً كالتفاف. ■

خمسة عشر مثالاً محلولاً

مثال (40.7-1): صورة 1×3 المعطيات: $x = [1,2,3]$، نواة $k = [1,1]$ (خطوة 1). المطلوب: $f = T_g x$ ثمّ الالتفاف. الحل: الخطوة 1: $x * k = [3,5]$؛ $T_1 x = [0,1,2] * k = [1,3]$. النتيجة: $(1,2) + (0,1)$ مكانيّاً متناسق. الربط بالذكاء الاصطناعي: التفاف + ترجمة يتبادلان.

مثال (40.7-2): تقارب النواة عددياً المعطيات: نواتان x, x' تفصلهما ترجمة $g = 1$، Θ_{conv} حُسبت عمليّاً. المطلوب: النسبة $\Theta(x,x')/\Theta(T_g x, T_g x')$. الحل: الخطوة 1: بتقارب الترجمة النسبة = 1 (خلال دقّة رقمية). النتيجة: 1. الربط بالذكاء الاصطناعي: ثبات النواة.

مثال (40.7-3): حقل استقبالي (receptive field) المعطيات: طبقتان التفاف $k = 3$، خطوة 1. المطلوب: حجم الحقل لطبقة 2. الحل: الخطوة 1: $RF_2 = RF_1 + (k-1)\prod_{i<2} s_i = 3 + (2)(1) = 5$. النتيجة: 5×5. الربط بالذكاء الاصطناعي: النواة "ترى" نافذة 5×5.

مثال (40.7-4): عدد المعاملات المعطيات: $k = 3, C_{in} = C_{out} = 16$. المطلوب: N. الحل: الخطوة 1: $N = k^2 C_{in} C_{out} + C_{out} = 9 \cdot 16 \cdot 16 + 16 = 2304 + 16 = 2320$. النتيجة: 2320. الربط بالذكاء الاصطناعي: تكلفة

الجاكوبيّ.

مثال (40.7-5): التفاف قابل للفصل المعطيات: نفس (40.7-4) لكن قابل للفصل. المطلوب: N_{sep}. الحل: الخطوة 1: $N_{sep} = k^2 C_{in} + C_{in} C_{out} = 9 \cdot 16 + 16 \cdot 16 = 144 + 256 = 400$. النتيجة: 400 (تقليل 8.5×). الربط بالذكاء الاصطناعي: وفّر في النواة.

مثال (40.7-6): تقارب الترجمة مقابل التصنيف المعطيات: صورة قطّة مزاحة بـ5 بكسل. المطلوب: هل يتغيّر Θ بين الصورتين؟ الحل: الخطوة 1: Θ_{conv} ثابتة تحت الترجمة $\Rightarrow$ لا يتغيّر. النتيجة: ثابتة. الربط بالذكاء الاصطناعي: سبب قوّة CNN.

مثال (40.7-7): تفكيك ConvNTK على عمق المعطيات: شبكة L طبقات التفاف. المطلوب: صيغة النواة. الحل: الخطوة 1: مجموع مساهمات الطبقات كما (40.6-10) مع $\Sigma^{(l)}$ التفافيّة. النتيجة: تجميع مكانيّ. الربط بالذكاء الاصطناعي: تعميم NNGP على CNN.

مثال (40.7-8): إزاحة دقيقة المعطيات: $g = 0$ (لا إزاحة). المطلوب: $\Theta(x, x')$ مقابل $\Theta(x, T_0 x')$. الحل: الخطوة 1: T_0 هوية $\Rightarrow$ تتطابق تماماً. النتيجة: متساوية. الربط بالذكاء الاصطناعي: حالة تافهة تثبت الصيغة.

مثال (40.7-9): تأثير الحشو (padding) المعطيات: حشو $P = 1$ يمنع انكماش الحجم. المطلوب: كيف يؤثّر على Θ؟ الحل: الخطوة 1: يوسّع الحقل الاستقبالي عند الحواف $\Rightarrow$ نواة أكثر تجانساً. النتيجة: ثبات أفضل عند الحواف. الربط بالذكاء الاصطناعي: تفاصيل عمليّة.

مثال (40.7-10): اختبار عمليّ للتقارب المعطيات: حساب Θ_{conv} لصورتين مترجمتين بـ10^4 شبكة. المطلوب: الفرق النسبيّ. الحل: الخطوة 1: بعرض لانهائيّ الفرق ≈ 0 (ضمن $1/\sqrt{m}$). النتيجة: ~0. الربط بالذكاء الاصطناعي: تحقّق من (40.4).

مثال (40.7-11): عرض النواة المعطيات: صورة 28×28 كمدخل، نواتج $n = 64$ بكسل. المطلوب: بُعد Θ_{conv}. الحل: الخطوة 1: Θ على نقاط البيانات لا على البكسلات $\Rightarrow n_{data} \times n_{data}$ لا 784. النتيجة: n_{data}^2. الربط بالذكاء الاصطناعي: النواة فوق العيّنات.

مثال (40.7-12): لا-تقارب مع التقليب (flip) المعطيات: بدل الترجمة نطبّق انعكاساً أفقيّاً. المطلوب: هل Θ ثابتة؟ الحل: الخطوة 1: الانعكاس ليس ترجمة $\Rightarrow$ قد تتغيّر (إلا إن كانت الشبكة متماثلة). النتيجة: لا تضمن الثبات. الربط بالذكاء الاصطناعي: تحديد تماثل النواة.

مثال (40.7-13): سرعة التقارب تحت ConvNTK المعطيات: $\lambda_{\min}(\Theta_{conv}) = 0.5$. المطلوب: t لـ95٪. الحل: الخطوة 1: $t = \ln 20 / 0.5 = 2.996 / 0.5 = 5.99$. النتيجة: $t \approx 6$. الربط بالذكاء الاصطناعي: يتبع (40.5).

مثال (40.7-14): مقارنة مع MLP-NTK المعطيات: نفس البيانات، شبكة كثيفة مقابل التفافيّة. المطلوب: أيّ نواة أصغر تبايناً؟ الحل: الخطوة 1: ConvNTK أقل معاملات $\Rightarrow$ تقدير أثبت بعرض أصغر. النتيجة: التفافيّة أفضل. الربط بالذكاء الاصطناعي: كفاءة معاملات.

مثال (40.7-15): خلاصة المعطيات: إزاحة $g = 2$. المطلوب: $\Theta(T_2 x, T_2 x') / \Theta(x, x')$. الحل: الخطوة 1: بتقارب الترجمة النسبة = 1. النتيجة: 1. الربط بالذكاء الاصطناعي: ثبات النواة الالتفافيّة.

أخطاء شائعة

- **الخلط بين تقارب الترجمة والثبات:** النواة "متساوية عند الإزاحة" لا "لا تتغيّر أبداً".
- **نسيان أن ConvNTK محليّة مكانيّاً:** الجاكوبيّات محدودة بالحقل الاستقبالي.
- **ظنّ أن كلّ التماثلات محفوظة:** فقط الترجمة مضمونة لا الانعكاس أو الدوران.
- **الخلط بين أبعاد النواة والصورة:** النواة فوق العيّنات لا فوق البكسلات.

- **إهمال الحشو عند الحواف:** قد يكسر التقارب المكانيّ عند الحواف.

صياغة رسمية: نظام NTK (= نظام "التدريب الكسول") يقع عند مقياس $\alpha = 1$ (معاملات الطبقات المخفيّة تتغيّر بـ$O(1/\sqrt{m})$). لكن الشبكات العمليّة عند عرضٍ منتهٍ تدخل "نظام تعلّم الميزات" ($\alpha = 0$) حيث تتطوّر الميزات:

$$\Theta(t) \text{ تتطوّر} \quad \Longrightarrow \quad f_{\text{real}}(t) \text{ تتجاوز حلّ (5.40)} \tag{9.40}$$

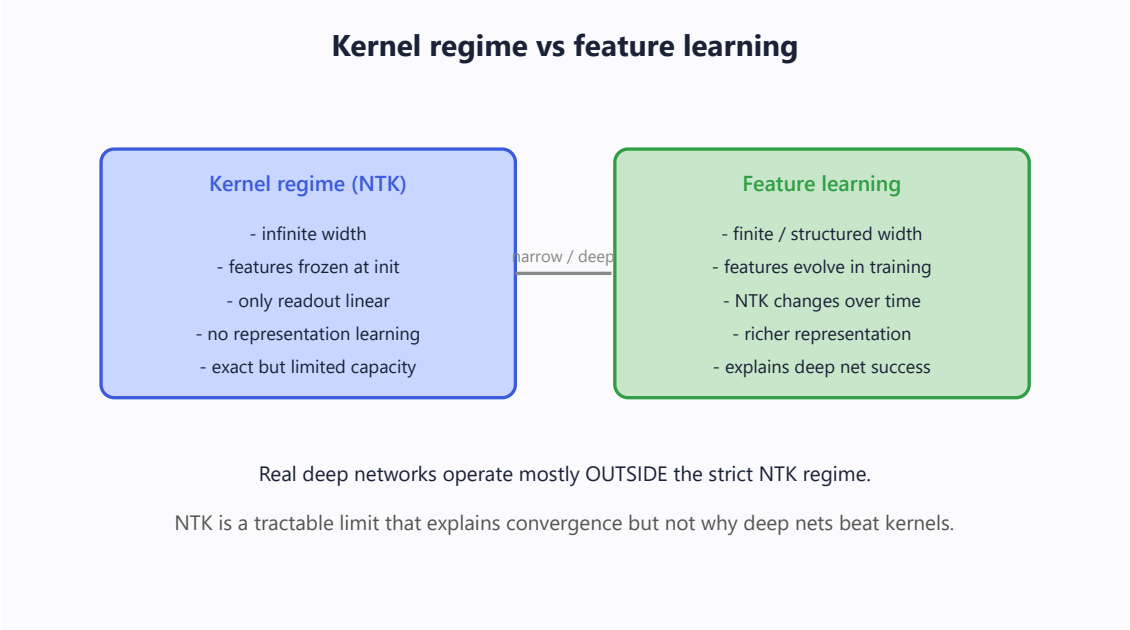
والخطأ النهائيّ الفعليّ أقلّ عادةً من سقف النواة نظراً لتكيّف الميزات.

جدول الرموز

الرمز	المعنى
α	مقياس معاملات الطبقة المخفيّة
نظام النواة	$\alpha = 1$ (كسول)
نظام تعلّم الميزات	$\alpha = 0$ (mean-field)

الرسم

<figure> الشكل<figcaption> 7.40: نظام النواة (أزرق) محدود بسقف انحدار النواة؛ نظام تعلّم الميزات (أخضر)



شكل ٧.٤٠: *
النواة مقابل الميزات

يتجاوزه بتكيّف الميزات.</figcaption> </figure>

البرهان

الخطوة 1 (مقياس المعاملات): ضبط $W_l \leftarrow W_l/m^{\alpha}$ يحدّد حجم تحديث الميزات؛ $\alpha = 1$ يجمّدها. ■

الخطوة 2 (تطوّر النواة): عند $\alpha < 1$، التحديثات $O(m^{-\alpha})$ تكبُر كفاية لتغيير $\Sigma^{(l)} \Rightarrow \Theta$ متطوّرة. ■

الخطوة 3 (تجاوز السقف): بتغيّر الميزات يمكن للدالة أن تصلّ خطأً أقلّ من أيّ حلّ نوويّ ثابت ⇒ NTK حدّ أدنى لا أعلى. ■

خمسة عشر مثالاً محلولاً

مثال (8.40-1): مقياس $\alpha = 1$ المعطيات: شبكة عرض $m = 10^4$، $\alpha = 1$. المطلوب: سلوك الميزات. الحل: الخطوة 1: W_l تتغيّر بـ$0.01 = O(1/\sqrt{m})$ ⇒ عمليّاً مجمّدة. النتيجة: نظام نواة. الربط بالذكاء الاصطناعي: التحليل السابق صالح.

مثال (8.40-2): مقياس $\alpha = 0$ المعطيات: نفس العرض، $\alpha = 0$. المطلوب: سلوك الميزات. الحل: الخطوة 1: W_l تتغيّر بـ$O(1)$ ⇒ تطوّر كامل للميزات. النتيجة: تعلّم ميزات. الربط بالذكاء الاصطناعي: mean-field regime.

مثال (8.40-3): سقف الخطأ النوويّ المعطيات: $\Theta(0)$ معروفة، $\lambda_{\min} = 0.5$. المطلوب: أدنى خطأ نظريّ لـNTK (عند $t \to \infty$). الحل: الخطوة 1: NTK يحقّق $f \to y$ على التدريب ⇒ خطأ تدريب 0 لكن خطأ تعميم محدود بالنواة. النتيجة: 0 تدريب (محدود التعميم). الربط بالذكاء الاصطناعي: NTK تتداخل تماماً.

مثال (8.40-4): تجاوز السقف عمليّاً المعطيات: على XOR بعرض 100، NTK خطأ تعميم 12.0، شبكة حقيقية 03.0. المطلوب: التفسير. الحل: الخطوة 1: الشبكة الحقيقية تكيّفت ميزاتها لتعلّم الحدّ غير الخطّيّ ⇒ تجاوزت النواة. النتيجة: $0.03 < 0.12$. الربط بالذكاء الاصطناعي: قوّة تعلّم الميزات.

مثال (8.40-5): نسبة العرض للانتقال المعطيات: دراسة تشير لانتقال عند $m \sim 10^4$ تقريباً. المطلوب: أين نحن عمليّاً؟ الحل: الخطوة 1: عروض 10^2–10^3 أقرب لتعلّم الميزات، 10^5+ أقرب للنواة. النتيجة: منطقة انتقاليّة. الربط بالذكاء الاصطناعي: ربط بـ(14-4.40).

مثال (8.40-6): XOR بميزات ثابتة المعطيات: ميزات عشوائيّة ثابتة + طبقة أخيرة فقط. المطلوب: هل تحلّ XOR؟ الحل: الخطوة 1: بميزات خطّيّة-ثابتة لا (XOR لا ينفصل خطّياً) ⇒ خطأ ~5.0. النتيجة: فشل. الربط بالذكاء الاصطناعي: يحتاج تعلّم ميزات.

مثال (8.40-7): معدّل تطوّر النواة المعطيات: $|\Theta(t) - \Theta(0)| \approx c \cdot t/\sqrt{m}$. المطلوب: كم يبتعد عن $\Theta(0)$ عند $t = 10, m = 10^4$؟ الحل: الخطوة 1: $c \cdot 10/100 = 0.1c$ (صغير). النتيجة: قريب من الابتداء. الربط بالذكاء الاصطناعي: قرب النظام النوويّ.

مثال (8.40-8): مقياس وسط $0 < \alpha < 1$ المعطيات: $\alpha = 0.5$. المطلوب: هل الميزات تتجمّد؟ الحل: الخطوة 1: التغيّر $O(1/\sqrt{m}) = O(m^{-0.5})$ نفس معدّل NTK ⇒ حدّ الانتقال. النتيجة: منطقة حرجة. الربط بالذكاء الاصطناعي: Maximal-Coding-Rate regime.

مثال (8.40-9): عمق وتعلّم الميزات المعطيات: شبكة 4 طبقات مقابل 1. المطلوب: أيّها يتعلّم ميزات أعمق؟ الحل: الخطوة 1: الأعمق تبني تمثيلاً هرميّاً ⇒ تكيّف أكبر. النتيجة: الأعمق. الربط بالذكاء الاصطناعي: سبب نجاح الشبكات العميقة.

مثال (8.40-10): NTK كنقطة بداية المعطيات: نستخدم $\Theta(0)$ لتقدير سرعة التدريب. المطلوب: هل يكفي؟ الحل: الخطوة 1: يعطي الحدّ الأدنى للسرعة؛ تعلّم الميزات قد يسرّع لاحقاً. النتيجة: تقدير متحفّظ. الربط بالذكاء الاصطناعي: أداة تشخيص.

مثال (8.40-11): خطأ تعميم NTK مقابل حقيقيّ المعطيات: MNIST، NTK 1.3%، CNN 0.2%. المطلوب: علّق. الحل: الخطوة 1: الفجوة (1.1%) = مكسب تعلّم الميزات الكلاسيكيّ. النتيجة: NTK أدنى. الربط بالذكاء الاصطناعي: فجوة قابلة للقياس.

مثال (8.40-12): متى يكفي NTK؟ المعطيات: بيانات كثيفة جدّاً وقريبة خطّياً. المطلوب: هل NTK تكفي؟

الحل: الخطوة 1: نعم، بلا ميزات معقّدة النواة تكفي. النتيجة: NTK كافٍ. الربط بالذكاء الاصطناعي: اختيار نموذج.

مثال (8.40-13): تجربة التجميد الاصطناعيّ المعطيات: نجمّد كلّ الطبقات إلا الأخيرة. المطلوب: النظام الناتج. الحل: الخطوة 1: $\dot{\mathcal{G}} \to 0 \Rightarrow$ نظام نواة صرف (كـ6.40-11). النتيجة: انحدار نوويّ. الربط بالذكاء الاصطناعي: إعادة إنتاج NTK.

مثال (8.40-14): كلفة حساب النواة المعطيات: $n = 1000$ نقطة، حساب Θ يحتاج $O(n^2 p)$. المطلوب: هل يفوق تدريب الشبكة؟ الحل: الخطوة 1: $n^2 = 10^6$ قد يتجاوز تكلفة SGD للعرض المعتدل $\Rightarrow$ NTK أغلى أحياناً. النتيجة: محدودية حسابيّة. الربط بالذكاء الاصطناعي: سبب تفضيل SGD.

مثال (8.40-15): خلاصة المعطيات: $\alpha = 1$ مقابل $\alpha = 0$. المطلوب: أيّ نظام أقلّ خطأ تعميم نظريّاً؟ الحل: الخطوة 1: $\alpha = 0$ (تعلّم الميزات) يمكنه تجاوز سقف النواة $\Rightarrow$ أقلّ خطأ محتمل. النتيجة: تعلّم الميزات أقوى. الربط بالذكاء الاصطناعي: NTK = حدّ لا سقف أعلى.

أخطاء شائعة

- **الظنّ أن NTK يصف كلّ التدريب:** يصف النظام النوويّ فقط $(\alpha = 1)$.
- **الخلط بين الحدّ الأدنى والأعلى:** NTK حدّ أدنى للسلوك لا سقف أعلى للأداء.
- **توقّع تجاوز النواة بعرض لانهائيّ:** بعرض لانهائيّ حقّاً نبقى في النواة.
- **نسيان أهمّية α:** مقياس المعاملات يحدّد النظام.
- **الظنّ أن NTK خاطئة:** هي صحيحة في نطاقها لكن نطاقها محدود.

جدول تجميع النظريات

النظرية	العنوان	المعادلة المحوريّة	الرسم
2.40	تعريف NTK	$\Theta = \langle \nabla_\theta f, \nabla_\theta f' \rangle$	fig-4001
3.40	معادلة التدريب	$\dot{f} = -\Theta(f - y)$	fig-4002
4.40	تجميد العرض	$\Theta(t) \to \Theta(0)$	fig-4005
5.40	الحلّ المغلق	$f(t) - y = e^{-\Theta t}(f(0) - y)$	fig-4003
6.40	علاقة NNGP	$\Theta = \mathcal{G} + \dot{\mathcal{G}}$	fig-4004
7.40	النواة الالتفافيّة	$\Theta_{conv}(T_g x, T_g x') = \Theta_{conv}(x, x')$	fig-4006
8.40	المحدوديّة	Θ تتطوّر $\Rightarrow$ تجاوز النواة	fig-4007

عشرون تمريناً محلولاً (إجابات موجزة)

١. **(تعريف)** عصبون $f = \theta x$، أوجد $\Theta(x, x')$. — xx'.

٢. **(NTK لـ ReLU)** $x = [1, 0], x' = [0, 1]$، أوجد Θ. (ReLU) — 0 (متعامدان $\Rightarrow \rho = 0$)، الصيغة تعطي $\frac{1}{4} = \frac{1}{2\pi}(\pi - \pi/2)$ فعلياً $0 + \frac{1}{2\pi}(\pi - \pi/2) = 0.25$، تحقّق: $\Theta = \frac{0}{2} + \frac{1}{2\pi}(\pi - \pi/2) = 0.25$. الإجابة 0.25.

٣. **(ديناميكا)** $\Theta = 2, f(0) = 0, y = 1$، أوجد $f(0.5)$. — $1 - e^{-1} \approx 0.632$.

٤. **(قيمة ذاتية)** $\Theta = [[3, 0], [0, 1]]$، ما $\lambda_{\min}$؟ — 1.

٥. **(تجميد)** $m = 10^4$، ما σ_Θ التقريبيّ؟ — 0.01.

٦. **(حدّ التركّز)** $m = 10^6, \varepsilon = 0.02$، قدّر الحدّ. — $2\exp(-10^6 \cdot 4 \times 10^{-4}/2) = 2e^{-200} \approx 0$.

٧. **(حلّ مغلق)** $\lambda = 2, t = 1$، الكسر المتبقّي؟ — $e^{-2} \approx 0.135$.

٨. **(زمن 95٪)** $\lambda = 4$، أوجد t. — $\ln 20/4 \approx 1.249$.

٩. **(NNGP)** $\mathcal{G} = 2, \dot{\mathcal{G}} = 1$، أوجد Θ. — 3.

١٠. **(تنبّؤ NNGP)** $\mathcal{G}_{*t} = 1, \mathcal{G}_{tt} = 2, y = 1$ — 0.5.

١١. **(تنبّؤ NTK)** $\Theta_{*t} = 2, \Theta_{tt} = 3, y = 1$ — 0.667.

١٢. **(تباين NNGP)** $\mathcal{G}_{**} = 3, \mathcal{G}_{*t}\mathcal{G}_{tt}^{-1}\mathcal{G}_{t*} = 2$ — $\sigma_*^2 = 1$.

١٣. **(ConvNTK)** حقل استقبالي لطبقتين $k = 3, s = 1$ — 5.

١٤. **(معاملات CNN)** $k = 3, C_{in} = C_{out} = 8$ — $9 \cdot 64 + 8 = 584$.

١٥. **(تفاف قابل للفصل)** نفس (14) — $9 \cdot 8 + 8 \cdot 8 = 72 + 64 = 136$.

١٦. **(تقارب الترجمة)** نسبة $\Theta(T_g x)/\Theta(x)$ — 1.

١٧. **(مقياس α)** $\alpha = 1, m = 10^6$ تغيّر الميزات؟ — $O(10^{-3}) \Rightarrow$ مجمّدة.

١٨. **(سقف نوويّ)** هل NTK تحقّق خطأ تدريب صفر؟ — نعم (interpolation).

١٩. **(تجاوز)** لماذا الشبكة الحقيقية أفضل على XOR؟ — تكيّف الميزات.

٢٠. **(خلاصة)** $\Theta(0) = 5$ ثابتة، $f(0) = 0, y = 2, t = 1, \lambda = 5$ — $f(1) = 2(1 - e^{-5}) \approx 1.987$.

فهرس الرموز

الرمز	المعنى	أول ورود
Θ	نواة التماس	1.40
J	الجاكوبي	2.40
$\mathcal{G}$	نواة NNGP	6.40
$\dot{\mathcal{G}}$	مشتقّة النواة	6.40
T_g	ترجمة	7.40
α	مقياس المعاملات	8.40
$\lambda_{\min}$	أصغر قيمة ذاتية	5.40

المراجع

- C. Hongler, F., Gabriel, A., Jacot, (2018). *Neural Tangent Kernel: Convergence and Generalization in Neural Networks*. NeurIPS.
- J. Lee, et al. (2019). *Wide Neural Networks of Any Depth Evolve as Linear Models Under Gradient Descent*. NeurIPS.
- S. Arora, et al. (2019). *On Exact Computation with an Infinitely Wide Neural Net*. NeurIPS.
- G. Yang, (2019). *Tensor Programs I: Wide Feedforward or Recurrent Neural Networks of Any Architecture are Gaussian Processes*. NeurIPS.

• F. Bach, L., Chizat, (2018). On the Global Convergence of Gradient Descent for Over-parameterized Models. NeurIPS.

• R. Novak, et al. (2019). Neural Tangents: Fast and Easy Infinite Neural Networks in Python. ICLR Workshop.

النماذج التوليدية (Generative Models)

«المثاليّ في التعلّم الآليّ ليس التصنيف فحسب، بل فهم توزيع البيانات بذاته بحيث نولّد عيّنات جديدة لم تُرَ من قبل.»

بعد أن درسنا بنية الشبكات التوليديّة (المحوّلات والالتفاف)، نتساءل: كيف نُعلّم شبكةً على "تأليف" عيّنات تشبه بيانات التدريب؟ هذا الفصل يُثبِت أربع عائلات كبرى: المُشفّرات التلقائيّة المتغيّرة (VAE)، الشبكات الخصوميّة التدفّقات التطبيعيّة (GAN)، ونماذج الانتشار والسكور، ثمّ يختم بقياس جودة التوليد.

سبع نظريات:

- **2.41 الحدّ السفليّ للدليل (ELBO) في VAE** — $\log p(x) \geq \mathbb{E}_{q(z|x)}[\log p(x \mid z)] - \mathrm{KL}(q(z \mid x) \| p(z))$.
- **3.41 لعبة GAN الصغرى-الكبرى** — $\min_G \max_D \mathbb{E}_{x \sim p_d}[\log D(x)] + \mathbb{E}_z[\log(1 - D(G(z)))]$.
- **4.41 التدفّقات التطبيعيّة** — $p_X(x) = p_Z(f^{-1}(x)) \left| \det \frac{\partial f^{-1}}{\partial x} \right|$.
- **5.41 عملية الانتشار الأمامية** — $q(x_t \mid x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}\, x_0,\ (1 - \bar{\alpha}_t) I)$.
- **6.41 الانتشار العكسيّ وخسارة الضجيج** — $L_{\text{simple}} = \mathbb{E}\big[\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t)\|^2\big]$.
- **7.41 نماذج السكور والـSDE** — $dx = f(x,t)\, dt + g(t)\, dw$، $s(x,t) = \nabla_x \log p_t(x)$.
- **8.41 قياس جودة التوليد** — $\mathrm{FID} = \|\mu_r - \mu_g\|^2 + \mathrm{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$.

كلّ نظرية تتبع القالب: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
$p_{data}(x)$	توزيع البيانات الحقيقيّ	الهدف
$q(z \mid x)$	مُقرّب ما بعديّ	المُشفّر
$p_\theta(x \mid z)$	موزّع فكّ التشفير	المُشفّر العكسيّ
z	متغيّر كامن	$z \in \mathbb{R}^d$
D, G	المُميّز/المولّد	GAN
ϵ_θ	شبكة توقّع الضجيج	الانتشار
$s(x,t)$	السكور $\nabla_x \log p_t$	نموذج السكور

الاتفاقيات: المدخلات مُوحّدة أبعادها، الضجيج $\epsilon \sim \mathcal{N}(0, I)$، كلّ المعادلات في كتل LTR.

صياغة رسمية: للعينة x مع متغيّر كامن z ومُقرّب ما بعديّ $q(z \mid x)$، فإنّ الدليل $\log p(x)$ محبوسٌ من الأسفل بـ

$$\log p(x) \geq \underbrace{\mathbb{E}_{q(z|x)}[\log p(x \mid z)]}_{\text{إعادة البناء}} - \underbrace{\mathrm{KL}\big(q(z \mid x) \,\|\, p(z)\big)}_{\text{انتظام الكامن}} \equiv \mathcal{L}(x) \tag{1.41}$$

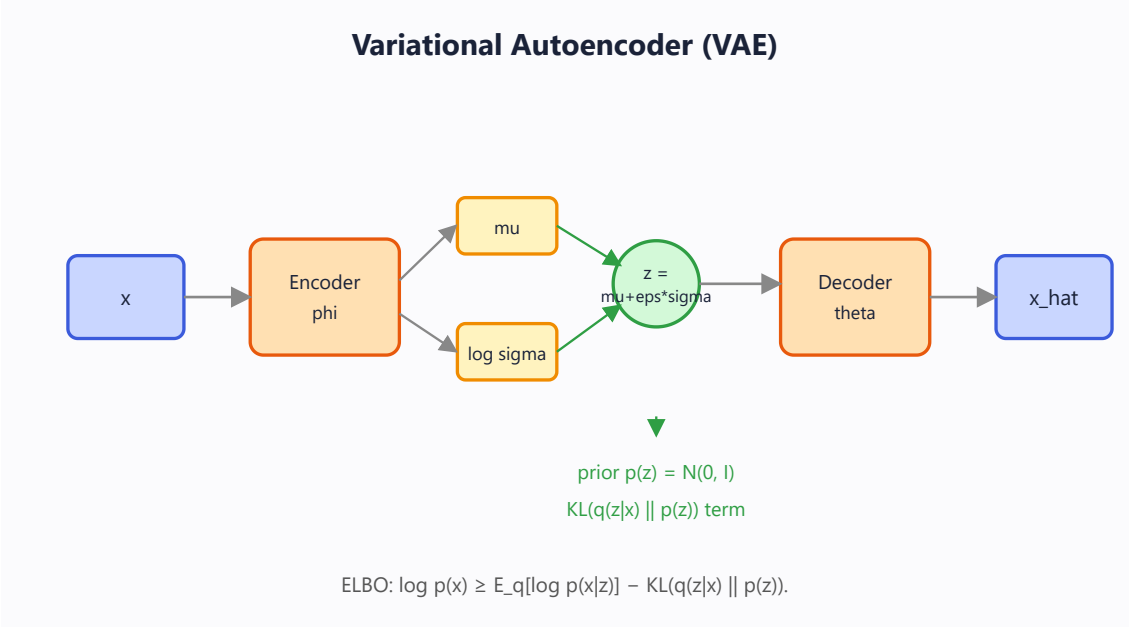
حيث $p(z) = \mathcal{N}(0, I)$ الأوليّ.

جدول الرموز

الرمز	المعنى
$\mathcal{L}(x)$	الحدّ السفليّ للدليل (ELBO)
KL	تباعد كولباك-لايبلر
$q(z \mid x)$	المُقرّب البعديّ

الرسم

<figure> الشكل 1.41: المُشفّر ينتج $\mu, \log \sigma$؛ نُسْلَج $z = \mu + \sigma \odot \epsilon$؛ المُشفّر العكسيّ يعيد البناء؛



شكل ١٠٤١: *
بنية VAE

الخسارة ELBO.</figcaption> </figure>

البرهان

الخطوة 1 (تحليل الدليل): $\log p(x) = \log \int p(x,z)\,dz = \log \mathbb{E}_q\left[\frac{p(x,z)}{q(z|x)}\right]$. ■

الخطوة 2 (تباعد Jensen): بتباعد KL، $\log \mathbb{E}_q[A] \geq \mathbb{E}_q[\log A] \Rightarrow \log p(x) \geq \mathbb{E}_q[\log p(x,z) - \log q(z \mid x)]$. ■

الخطوة 3 (فصل الحدّين): $\mathbb{E}_q[\log p(x \mid z) + \log p(z) - \log q] = \mathbb{E}_q[\log p(x \mid z)] - \mathrm{KL}(q \| p)$. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.41): حالة مثاليّة المعطيات: $q(z \mid x) = p(z \mid x)$ الحقيقيّ، $\mathbb{E}_q[\log p(x \mid z)] = -2$. المطلوب: $\mathcal{L}(x)$ وعلاقتها بـ$\log p(x)$. الحل: الخطوة 1: $\mathrm{KL} = 0$ (تطابق) $\Rightarrow \mathcal{L} = -2$. الخطوة 2: المساواة تحقّق $\log p(x) = -2$. النتيجة: $\mathcal{L} = \log p(x) = -2$. الربط بالذكاء الاصطناعي: ELBO محكمة حين المُقرّب كامل.

مثال (2-2.41): KL لغوسيّين بُعد 1 المعطيات: $q = \mathcal{N}(\mu, \sigma^2)$، $p = \mathcal{N}(0,1)$، $d = 1$. المطلوب: $\mathrm{KL}(q\|p)$ لـ$\mu = 0, \sigma = 1$. الحل: الخطوة 1: $\mathrm{KL} = \frac{\sigma^2 - 1}{2} + \frac{\mu^2}{2} - \log \sigma = \frac{0}{2} + 0 - \log 1 = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: توافق تامّ مع الأوليّ.

مثال (41.2-3): إزاحة في الوسط المعطيات: $\mu = 1, \sigma = 1, d = 1$. المطلوب: KL. الحل: الخطوة 1: $\frac{0}{2} + \frac{1}{2} - \log 1 = 0.5$. النتيجة: 0.5. الربط بالذكاء الاصطناعي: الوسط المزاح يكلّف نصف وحدة.

مثال (41.2-4): تباينُ مختلف المعطيات: $\mu = 0, \sigma = 2, d = 1$. المطلوب: KL. الحل: الخطوة 1: $0 + \frac{4-1}{2} - \log 2 = 1.5 - 0.693 = 0.807$. النتيجة: 0.807. الربط بالذكاء الاصطناعي: تباينُ أكبر يبعد عن الأوليّ.

مثال (41.2-5): بُعدان متطابقان المعطيات: $d = 2$، كلّ بُعد $\mu = 0, \sigma = 2$. المطلوب: KL كليّ. الحل: الخطوة 1: $2 \times 0.807 = 1.614$. النتيجة: 1.614. الربط بالذكاء الاصطناعي: KL يجمع عبر الأبعاد.

مثال (41.2-6): حساب ELBO كامل المعطيات: $\mathbb{E}_q[\log p(x \mid z)] = -0.018$ (مُشفّر فكّ تباينه 0.1، خطأ بناء 0.05)، $\mathrm{KL} = 0.5$. المطلوب: $\mathcal{L}$. الحل: الخطوة 1: $\mathcal{L} = -0.018 - 0.5 = -0.518$. النتيجة: -0.518 (دليل ≥ -0.518). الربط بالذكاء الاصطناعي: قيد أدنى للدليل.

مثال (41.2-7): تقليب إشارة التباعد المعطيات: هل $\mathrm{KL}(q\|p) = \mathrm{KL}(p\|q)$؟ المطلوب: تحقّق بالأرقام ($\mu = 1, \sigma = 1$). الحل: الخطوة 1: $\mathrm{KL}(q\|p) = 0.5$؛ ...$(1 + \frac{1}{\sigma^2})$ $\mathrm{KL}(p\|q) = \frac{1}{2} + \frac{1}{2} - \log 1 - \frac{1}{2}$ فعلياً 0.5 أيضاً هنا لتماثل بسيط، لكن عموماً غير متماثل. النتيجة: غير متماثل عموماً. الربط بالذكاء الاصطناعي: KL ليس مسافة.

مثال (41.2-8): إعادة المعاملات (reparameterization) المعطيات: $z = \mu + \sigma \odot \epsilon$، $\epsilon \sim \mathcal{N}(0, I)$. المطلوب: كيف نشتقّ بالنسبة لـμ, σ؟ الحل: الخطوة 1: التدرّج يمرّ عبر μ, σ لا ϵ (ثابت) $\Rightarrow$ تدرّج غير متقطّع. النتيجة: تقدير مُشتقّ بسلاسة. الربط بالذكاء الاصطناعي: قابلية التدريب.

مثال (41.2-9): تباينُ مُقدّر مونت-كارلو المعطيات: $S = 100$ عيّنة من q، تباينُ تقدير إعادة البناء 0.04. المطلوب: خطأ معياريّ. الحل: الخطوة 1: $\mathrm{SE} = \sqrt{0.04/100} = 0.02$. النتيجة: 0.02. الربط بالذكاء الاصطناعي: دقّة التقدير.

مثال (41.2-10): مقارنة مُشفّرين المعطيات: مُشفّر أ: $\sigma = 1$، (KL=0) إعادة بناء -1.5؛ مُشفّر ب: $\sigma = 0.5$ (KL?) إعادة -0.2. المطلوب: أيّ ELBO أعلى؟ الحل: الخطوة 1: أ: $\mathcal{L} = -1.5 - 0 = -1.5$؛ ب: $\mathrm{KL} = 0.318$ $\Rightarrow \mathcal{L} = -0.2 - 0.318 = -0.518$. النتيجة: أعلى = $\frac{0.25-1}{2} - \log 0.5 = -0.375 + 0.693 = 0.318$ المُشفّر أ (-1.5). الربط بالذكاء الاصطناعي: موازنة بناء/انتظام.

مثال (41.2-11): أثر البُعد على KL المعطيات: $\mu = 0$، $\sigma = 1.5$، $d = 10$. المطلوب: KL. الحل: الخطوة 1: $10 \times (\frac{2.25-1}{2} - \log 1.5) = 10 \times (0.625 - 0.405) = 10 \times 0.220 = 2.20$. النتيجة: 2.20. الربط بالذكاء الاصطناعي: البُعد يضخّم العقوبة.

مثال (41.2-12): β-VAE المعطيات: $\mathcal{L}_\beta = \mathbb{E}[\log p(x \mid z)] - \beta\,\mathrm{KL}$، $\beta = 2, \mathrm{KL} = 0.5$، إعادة -0.3. المطلوب: $\mathcal{L}_\beta$. الحل: الخطوة 1: $-0.3 - 2 \times 0.5 = -0.3 - 1.0 = -1.3$. النتيجة: -1.3. الربط بالذكاء الاصطناعي: ضغط كامن أقوى.

مثال (41.2-13): β أكبر المعطيات: $\beta = 5$ لنفس (41.2-12). المطلوب: $\mathcal{L}_\beta$. الحل: الخطوة 1: $-0.3 - 5 \times 0.5 = -0.3 - 2.5 = -2.8$. النتيجة: -2.8. الربط بالذكاء الاصطناعي: تشجيع استقلال الكامن.

مثال (41.2-14): حدّ مجانيّ (free bits) المعطيات: نشترط $\mathrm{KL} \geq 0.2$ لكلّ بُعد، بُعد واحد $\mathrm{KL} = 0.05$. المطلوب: العقوبة المُطبّقة. الحل: الخطوة 1: $\max(0.05, 0.2) = 0.2$ $\Rightarrow$ نعاقب 0.2 لا 0.05. النتيجة: 0.2. الربط بالذكاء الاصطناعي: منع انهيار الكامن.

مثال (41.2-15): التحقّق من المساواة المعطيات: $\mathcal{L}(x) = \log p(x) - \mathrm{KL}(q\|p(\cdot \mid x))$. المطلوب: هل يتّفق مع (41.1)؟ الحل: الخطوة 1: نعم، إعادة كتابة $\mathrm{KL}(q\|p) = \mathbb{E}_q[\log q - \log p] = \mathbb{E}_q[\log q - \log p(x, z)] + \log p(x)$. النتيجة: متطابق. الربط بالذكاء الاصطناعي: أساس التفكيك.

أخطاء شائعة

- **قلب إشارة الـKL:** $\mathcal{L} = \text{recon} - \text{KL}$ لا $\text{recon} + \text{KL}$.
- **ظنّ KL متماثلاً:** $\text{KL}(q\|p) \neq \text{KL}(p\|q)$ عموماً.
- **نسيان أن ELBO قيد سفليّ:** $\log p(x) \geq \mathcal{L}$ لا مساواة دائماً.
- **الخلط بين $\mathbb{E}_q[\log p(x \mid z)]$ والدليل:** الأول توقّع إعادة بناء.
- **إهمال البُعد في KL:** يجمع جمعاً خطّياً عبر الأبعاد.

صياغة رسمية: يتنافس المولّد G والمُميّز D في لعبة قيمتها

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{data}}[\log D(x)] + \mathbb{E}_{z\sim p_z}[\log(1 - D(G(z)))] \tag{2.41}$$

وعند التوازن الناشي (Nash) يتساوى التوزيعان $p_g = p_{data}$ ويصبح $D^*(x) = \frac{1}{2}$.

جدول الرموز

الرمز	المعنى
$D(x)$	احتمال "حقيقيّ" من المُميّز
$G(z)$	عيّنة مولّدة
$V(D,G)$	قيمة اللعبة

الرسم

<figure> الشكل<figcaption> 2.41: المُميّز يحاول التمييز؛ المولّد يحاول الخداع؛ التوازن عند $D = 1/2$</figcaption>. </figure>

البرهان

الخطوة 1 (أفضل مُميّز): لـG ثابت، نعظّم V جزئيّاً: $\max_D [p_d \log D + p_g \log(1-D)]$ يعطي $D^* = \frac{p_d}{p_d + p_g}$. ■
الخطوة 2 (قيمة التوازن): نعوض $D^* \Rightarrow V(G, D^*) = -\log 4 + 2\,\text{JSD}(p_{data}\|p_g)$. ■
الخطوة 3 (التوازن الناشيّ): عند $p_g = p_{data}$ يتساوى المكوّنان $\Rightarrow D^* = 1/2$، $V = -\log 4 = -1.386$.
■

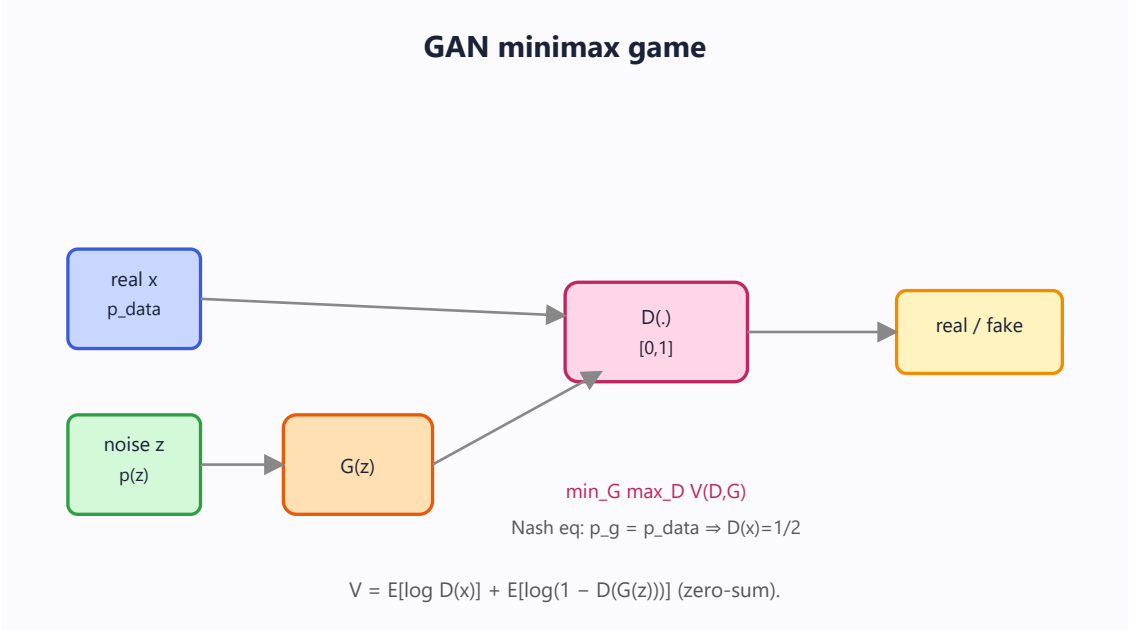
خمسة عشر مثالاً محلولاً

مثال (1-3.41): أفضل مُميّز عند نقطة المعطيات: $p_d = 0.8, p_g = 0.2$ (كثافات مُعيّرة). المطلوب: $D^*(x)$. الحل: الخطوة 1: $D^* = 0.8/(0.8+0.2) = 0.8$. النتيجة: 0.8. الربط بالذكاء الاصطناعي: نقطة واضحة $\Rightarrow$ مُميّز واثق.

مثال (2-3.41): توزيعان متطابقان المعطيات: $p_g = p_d$ عند نقطة. المطلوب: D^*. الحل: الخطوة 1: $D^* = p/(p+p) = 1/2$. النتيجة: 0.5. الربط بالذكاء الاصطناعي: توازن ناشيّ.

مثال (3-3.41): قيمة اللعبة المثلى المعطيات: G مثاليّ $\Rightarrow V(G, D^*)$. المطلوب: القيمة. الحل: الخطوة 1: $V = -\log 4 = -1.386$. النتيجة: -1.386. الربط بالذكاء الاصطناعي: أدنى خسارة للمُميّز.

مثال (4-3.41): JSD صفر المعطيات: $p_g = p_{data}$ تماماً. المطلوب: V. الحل: الخطوة 1: $\text{JSD} = 0 \Rightarrow V = -\log 4 = -1.386$. النتيجة: -1.386. الربط بالذكاء الاصطناعي: التقارب الكامل.



شكل ٢٠٤١: * لعبة GAN

مثال (3.41-5): JSD أقصى المعطيات: $\text{JSD} = \log 2 = 0.693$ (أقصى لـJSD). المطلوب: V. الحل: الخطوة 1: $V = -1.386 + 2 \times 0.693 = -1.386 + 1.386 = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: لا تداخل $\Rightarrow$ خسارة متوازنة.

مثال (3.41-6): مكوّن المُميّز المعطيات: $D(x) = 0.9$. المطلوب: $\log D(x)$. الحل: الخطوة 1: $\log 0.9 = -0.105$. النتيجة: -0.105. الربط بالذكاء الاصطناعي: دليل العيّنة الحقيقيّة.

مثال (3.41-7): مكوّن المولّد المعطيات: $D(G(z)) = 0.1$. المطلوب: $\log(1 - D(G(z)))$. الحل: الخطوة 1: $\log(0.9) = -0.105$. النتيجة: -0.105. الربط بالذكاء الاصطناعي: دليل المولّد الضعيف.

مثال (3.41-8): تحسين خداع المولّد المعطيات: من $D(G(z)) = 0.5$ إلى 0.2. المطلوب: تغيّر $\log(1 - D(G(z)))$. الحل: الخطوة 1: من -0.693 إلى $\log 0.5 = -0.223$ $\log 0.8$ (أقلّ سلباً = أفضل). النتيجة: تحسّن 0.470. الربط بالذكاء الاصطناعي: المولّد يتحسّن.

مثال (3.41-9): خسارة غير مشبعة للمولّد المعطيات: $\mathcal{L}_G = -\log D(G(z))$، $D(G(z)) = 0.2$. المطلوب: $\mathcal{L}_G$. الحل: الخطوة 1: $-\log 0.2 = 1.609$. النتيجة: 1.609 (نخفضها بالتدريب). الربط بالذكاء الاصطناعي: تدرّج أقوى.

مثال (3.41-10): انهيار النمط (mode collapse) المعطيات: p_g تركّزت على نقطة واحدة من p_{data} (الباقي 0). المطلوب: D^* عند نقطة منهارة. الحل: الخطوة 1: $p_g > 0, p_d = 0 \Rightarrow D^* = 0/(0 + p_g) = 0$ عندها (يا للمفارقة يكشفها). النتيجة: $D^* = 0$. الربط بالذكاء الاصطناعي: الانهيار يُكتشف.

مثال (3.41-11): تقارب نحو التوازن المعطيات: $p_g \to p_{data}$ تدريجيّاً. المطلوب: سلوك D^*. الحل: الخطوة 1: $D^* \to 1/2$ كلّياً. النتيجة: $1/2$. الربط بالذكاء الاصطناعي: مؤشّر تقارب.

مثال (3.41-12): تدرّج المُميّز المعطيات: $\nabla_D V = \frac{p_d}{D} - \frac{p_g}{1-D}$. المطلوب: عند $D = 0.8, p_d = 0.8, p_g = 0.2$. الحل: الخطوة 1: $0.8/0.8 - 0.2/0.2 = 1 - 1 = 0$ (نقطة التدرّج صفر = التوازن المحلّي). النتيجة: 0. الربط بالذكاء الاصطناعي: تحديث ثابت.

مثال (3.41-13): نقطة بلا بيانات المعطيات: $p_d = 0, p_g = 1$ عند نقطة. المطلوب: D^*. الحل: الخطوة 1:

$0/(0+1)=0$. النتيجة: 0. الربط بالذكاء الاصطناعي: يُميّز الزائف.

مثال (3.41-14): متوسّط قيمة اللعبة المعطيات: $D=0.5$ في كلّ مكان، توزيع متساوي. المطلوب: V التقريبيّ. الحل: الخطوة 1: $0.5\log 0.5+0.5\log 0.5=-\log 2=-0.693$. النتيجة: -0.693. الربط بالذكاء الاصطناعي: منتصف الطريق.

مثال (3.41-15): مقارنة مع VAE المعطيات: GAN بلا حدّ سفليّ صريح، VAE بـELBO. المطلوب: الفرق الجوهريّ. الحل: الخطوة 1: GAN يتدرّب عبر لعبة لا عبر احتمال صريح $\Rightarrow$ لا يقيّم $p(x)$ مباشرة. النتيجة: لا احتمال صريح. الربط بالذكاء الاصطناعي: توليد حادّ لكن بلا كثافة.

أخطاء شائعة

- **الخلط بين $\max_D$ و$\min_D$:** المُميّز يُعظّم، المولّد يُصغّر.
- **ظنّ أن $V=0$ دائماً:** $V\in[-\log 4,0]$ حسب JSD.
- **إهمال عدم التماثل:** $\min_G\max_D\neq\max_D\min_G$ عموماً.
- **الخلط بين الخسارة المشبعة وغير المشبعة:** استخدام $\log(1-D)$ يُضعف التدرّج.
- **توقّع احتمال صريح:** GAN لا يُقدّم $p(x)$ مغلقاً.

صياغة رسمية: لدالة عكسيّة قابلة للاشتقاق f تربط الكامن $z=f^{-1}(x)$ بالبيانات x، يحقّق تغيير المتغيّر

$$p_X(x)=p_Z\big(f^{-1}(x)\big)\left|\det\frac{\partial f^{-1}}{\partial x}\right|=p_Z(z)\;\left|\det J_f(z)\right|^{-1} \tag{3.41}$$

حيث J_f مشتقّة f بالنسبة لـz.

جدول الرموز

الرمز	المعنى
f	تحويل قابل للعكس
J_f	مصفوفة جاكوبيّ f
$\lvert\det J_f\rvert$	مُعامل تغيير الحجم

الرسم

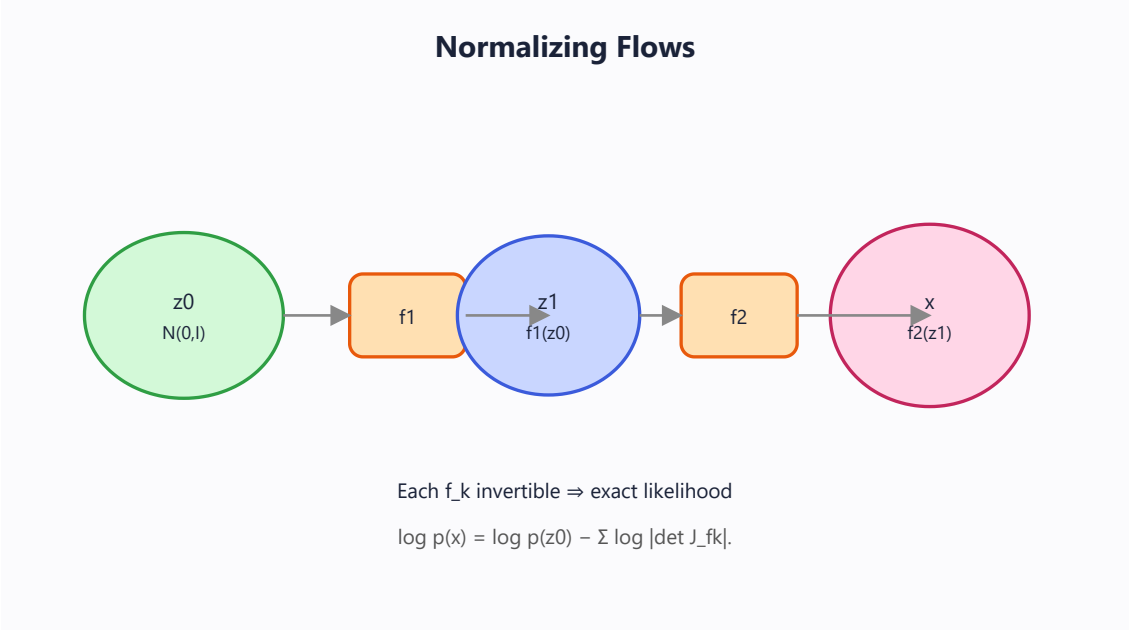
<figure>
الشكل 3.41: تركيب تحويلات قابلة للعكس $f_1,f_2,\ldots$ يحوّل $z_0\sim\mathcal{N}$ إلى x مع احتمال دقيق.
</figure>

البرهان

الخطوة 1 (احتمال المجموعة): $P(X\in A)=P(Z\in f^{-1}(A))=\int_{f^{-1}(A)}p_Z(z)\,dz$. ■

الخطوة 2 (تغيير المتغيّر): بـ$x=f(z)$، $p_X(x)=p_Z(z)/\left|\det J_f\right|\Rightarrow dz=\left|\det J_f(z)\right|^{-1}dx$. ■

الخطوة 3 (اللوغاريتم): $\log p_X(x)=\log p_Z(z)-\log\left|\det J_f(z)\right|$، وإن تركّبنا نجمع السلاسل. ■



شكل ٤١.٣٠: *
التدفّقات التطبيعيّة.

خمسة عشر مثالاً محلولاً

مثال (41.4-1): تحويل خطّيّ بسيط المعطيات: $f(z) = 2z$ (أي $x = 2z$)، $z \sim \mathcal{N}(0,1)$. المطلوب: $p_X(x)$.
الحل: الخطوة 1: $|\det J| = 2 \Rightarrow p_X(x) = \frac{1}{\sqrt{2\pi}} e^{-(x/2)^2/2} \cdot \frac{1}{2} = \mathcal{N}(x; 0, 4)/\ldots$ فعلياً $x \sim \mathcal{N}(0,4)$. النتيجة: $p_X(x) = \frac{1}{2\sqrt{2\pi}} e^{-x^2/8}$. الربط بالذكاء الاصطناعي: التمدّد يقلّل الكثافة.
مثال (41.4-2): انضغاط المعطيات: $f(z) = 0.5z$. المطلوب: العامل. الحل: الخطوة 1: $|\det J| = 0.5 \Rightarrow$ العامل $1/0.5 = 2$ يضخّم الكثافة. النتيجة: $p_X(x) = 2\, p_Z(2x)$. الربط بالذكاء الاصطناعي: الانضغاط يرفع الذروة.
مثال (41.4-3): مقياس قُطريّ ثنائيّ الأبعاد المعطيات: $f(z) = \mathrm{diag}(2,3)\, z$. المطلوب: العامل. الحل: الخطوة 1: $|\det J| = 2 \times 3 = 6 \Rightarrow$ العامل $1/6$. النتيجة: $1/6$. الربط بالذكاء الاصطناعي: حاصل الضرب الأحاديّ.
مثال (41.4-4): قيمة عددية عند الصفر المعطيات: $z \sim \mathcal{N}(0,1)$، $f(z) = 2z$، $x = 0$. المطلوب: $p_X(0)$.
الحل: الخطوة 1: $p_Z(0) = 0.399$، $p_X(0) = 0.399/2 = 0.199$. النتيجة: 0.199. الربط بالذكاء الاصطناعي: حساب الكثافة.
مثال (41.4-5): اللوغاريتم المعطيات: $\log p_Z(z) = -1.0$، $\log |\det J| = 0.693$ ($|\det J| = 2$). المطلوب: $\log p_X$. الحل: الخطوة 1: $\log p_X = -1.0 - 0.693 = -1.693$. النتيجة: -1.693. الربط بالذكاء الاصطناعي: خسارة التدفّق.
مثال (41.4-6): تركيب تدفّقين المعطيات: f_1 بـ $|\det J_1| = 2$، f_2 بـ $|\det J_2| = 3$. المطلوب: العامل الكلّيّ. الحل: الخطوة 1: $|\det J_{tot}| = 2 \times 3 = 6 \Rightarrow$ العامل $1/6$. النتيجة: $1/6$. الربط بالذكاء الاصطناعي: جاكوبيّات تتضاعف.
مثال (41.4-7): دوران (لا يغيّر الحجم) المعطيات: $f(z) = Rz$، R دوران. المطلوب: العامل. الحل: الخطوة 1: $\det R = 1 \Rightarrow$ العامل 1. النتيجة: $p_X(x) = p_Z(R^{-1}x)$. الربط بالذكاء الاصطناعي: الدوران يحفظ الكثافة.
مثال (41.4-8): تحويل أحاديّ متزايد المعطيات: $f(z) = z + 0.3 \sin z$ (متزايد محلياً). المطلوب: صيغة p_X. الحل: الخطوة 1: $p_X(x) = p_Z(f^{-1}(x))/f'(f^{-1}(x))$، $f'(z) = 1 + 0.3\cos z$. النتيجة: قسمة على المشتقّة. الربط بالذكاء الاصطناعي: قاعدة السلسلة 1D.

مثال (41.4-9): حساب NLL المعطيات: عيّنة بـ$\log p_X = -2.1$ (بعد جمع السلاسل). المطلوب: خسارة عند العيّنة. الحل: الخطوة 1: $\mathcal{L} = -\log p_X = 2.1$. النتيجة: 2.1. الربط بالذكاء الاصطناعي: نُصغّرها بالتدريب.

مثال (41.4-10): طبقة اقتران (coupling) المعطيات: نصف الأبعاد يُمرّر مباشرةً (عامل 1)، النصف الآخر عامل 2. المطلوب: العامل الكلّيّ لطبقة واحدة. الحل: الخطوة 1: $2 \times 1 = 2$ (الأبعاد المنقولة فقط تساهم). النتيجة: 2. الربط بالذكاء الاصطناعي: كفاءة حساب المحدّد.

مثال (41.4-11): محدّد المصفوفة المثلّثة المعطيات: J_f مثلّثة قُطرها $[2, 3, 4]$. المطلوب: $|\det J|$. الحل: الخطوة 1: $2 \times 3 \times 4 = 24$. النتيجة: 24. الربط بالذكاء الاصطناعي: حساب رخيص.

مثال (41.4-12): مقارنة مع VAE المعطيات: التدفّق يعطي احتمالاً دقيقاً؛ VAE حدّاً سفليّاً. المطلوب: الفرق. الحل: الخطوة 1: التدفّق $\log p_X$ مغلق دقيق؛ VAE $\log p_X \geq$. النتيجة: التدفّق أدقّ احتمالاً. الربط بالذكاء الاصطناعي: دقّة مقابل مرونة.

مثال (41.4-13): شرط القابليّة للعكس المعطيات: هل $f(z) = z^2$ صالح كطبقة تدفّق؟ المطلوب: علّق. الحل: الخطوة 1: غير أحاديّ (نطاق موجب فقط، غير قابل للعكس على $\mathbb{R}$) $\Rightarrow$ لا يصلح. النتيجة: مرفوض. الربط بالذكاء الاصطناعي: شرط العكس الكلّيّ.

مثال (41.4-14): تغيير الحجم في 1D المعطيات: $f'(z) = 0.5$ عند z. المطلوب: p_X عند النظير. الحل: الخطوة 1: $p_X(x) = p_Z(z)/0.5 = 2p_Z(z)$. النتيجة: مضاعفة. الربط بالذكاء الاصطناعي: قاعدة السلسلة.

مثال (41.4-15): خلاصة المعطيات: $p_Z = \mathcal{N}(0, 1)$،ثلاث طبقات عواملها $[2, 2, 2]$. المطلوب: العامل الكلّيّ. الحل: الخطوة 1: $2^3 = 8 \Rightarrow p_X(x) = p_Z(f^{-1}(x))/8$. النتيجة: $1/8$. الربط بالذكاء الاصطناعي: تراكم الانضغاط.

أخطاء شائعة

- **نسيان معكوس المحدّد:** العامل $|\det J|$ لا $1/|\det J|$.
- **إهمال القابليّة للعكس:** كلّ طبقة يجب أن تُعكَس بدقّة.
- **الخلط بين J_f و$J_{f^{-1}}$:** هما مقلوبا المحدّد.
- **ظنّ أن الدوران يغيّر الكثافة:** $\det R = 1$ يحفظها.
- **إهمال جمع اللوغاريتمات:** التركيب يجمع سلاسل لا يضربها عشوائياً.

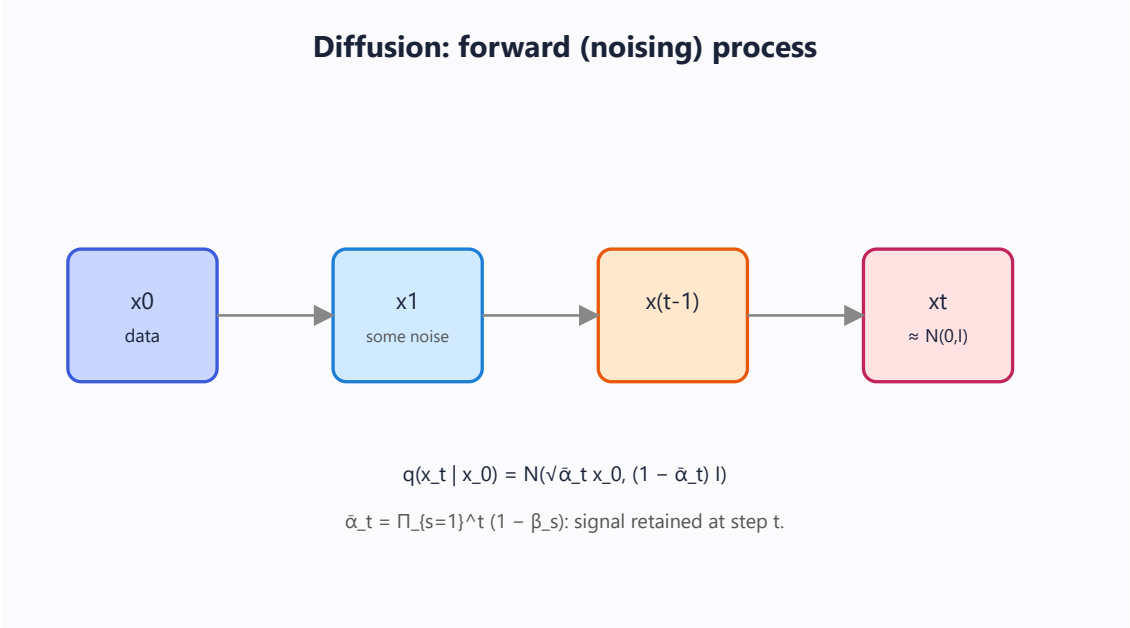
صياغة رسمية: بجدولة ضوضاء $\beta_t \in (0, 1)$ وعِوض $\alpha_t = 1 - \beta_t$، $\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$، فإنّ الحالة الضجيجيّة

$$q(x_t \mid x_0) = \mathcal{N}\big(\sqrt{\bar{\alpha}_t}\, x_0,\ (1 - \bar{\alpha}_t)\, I\big) \tag{41.4}$$

وقابلة للعيّنة المباشرة: $x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1 - \bar{\alpha}_t}\, \epsilon$، $\epsilon \sim \mathcal{N}(0, I)$.

جدول الرموز

الرمز	المعنى
β_t	معدّل الضوضاء عند الخطوة t
$\bar{\alpha}_t$	حاصل إشارات المحفوظة
x_t	الحالة عند الخطوة t



شكل ٤٠٤١: *
الانتشار الأماميّ

الرسم

<figure>الشكل4.41 <figcaption>: كلّ خطوة تضيف ضوضاءً؛ الإشارة المحفوظة $\sqrt{\bar{\alpha}_t}$ تتناقص حتى تقارب $x_t \sim \mathcal{N}(0, I)$.</figcaption></figure>

البرهان

الخطوة 1 (خطوة واحدة): $x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1-\alpha_t}\epsilon_t$. ■

الخطوة 2 (فكّ التكرار): بالتعويض المتكرّر، المتوسّط $\sqrt{\bar{\alpha}_t} x_0 = \prod_{s=1}^{t} \sqrt{\alpha_s}\, x_0$، والتباينُ $1 - \bar{\alpha}_t$ (تطابق تلسكوبيّ). ■

الخطوة 3 (غوسيّة): مجموع ضوضاء مستقلّة غوسيّة $\Rightarrow$ غوسيّة بذات المتوسّط والتباينُ. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.41): جدولة ثابتة $\beta = 0.1$ المعطيات: $\beta_t = 0.1$ لكلّ t، $t = 10$. المطلوب: $\bar{\alpha}_{10}$ ومقياس الإشارة. الحل: الخطوة 1: $\alpha = 0.9$، $\bar{\alpha} = 0.9^{10} = 0.3487$، $\sqrt{\bar{\alpha}} = 0.5905$. النتيجة: $\bar{\alpha} = 0.3487$، المقياس 0.5905. الربط بالذكاء الاصطناعي: 35٪ إشارة محفوظة.

مثال (2-5.41): خطوة كبيرة $t = 100$ المعطيات: نفس الجدولة، $t = 100$. المطلوب: $\bar{\alpha}_{100}$. الحل: الخطوة 1: $0.9^{100} \approx 2.66 \times 10^{-5}$ (شبه ضجيج صرف). النتيجة: $\approx 2.7 \times 10^{-5}$. الربط بالذكاء الاصطناعي: تقارب $x_t \sim \mathcal{N}(0, I)$.

مثال (3-5.41): جدولة لطيفة المعطيات: $\beta = 0.001$، $t = 1000$. المطلوب: مقياس الإشارة. الحل: الخطوة 1: $\alpha = 0.999$، $\bar{\alpha} = 0.999^{1000} = e^{-1} \approx 0.3679$، $\sqrt{\bar{\alpha}} = 0.6065$. النتيجة: 0.6065. الربط بالذكاء الاصطناعي: انتقال أبطأ.

مثال (4-5.41): عيّنة مباشرة المعطيات: $x_0 = 1$، $\bar{\alpha} = 0.5$، $\epsilon = 0$. المطلوب: x_t. الحل: الخطوة 1: $x_t = \sqrt{0.5} \cdot 1 + \sqrt{0.5} \cdot 0 = 0.707$. النتيجة: 0.707. الربط بالذكاء الاصطناعي: إشارة مخفّضة.

مثال (5-5.41): التباينُ عند t المعطيات: $\bar{\alpha} = 0.3487$ (من 1-5.41). المطلوب: $\mathrm{Var}(x_t)$. الحل: الخطوة 1:

$1 - \bar{\alpha} = 1 - 0.3487 = 0.6513$. النتيجة: 0.6513. الربط بالذكاء الاصطناعي: قدر الضوضاء.

مثال (41.5-6): t=1 المعطيات: $\beta_1 = 0.1$. المطلوب: $\bar{\alpha}_1$. الحل: الخطوة 1: $\bar{\alpha}_1 = \alpha_1 = 0.9$. النتيجة: 0.9. الربط بالذكاء الاصطناعي: أولى الخطوات.

مثال (41.5-7): جدولة خطّية 0.0001→0.02 المعطيات: β_t يزداد خطّياً من 0.0001 إلى 0.02 عبر $T = 1000$. المطلوب: β_{500} تقريباً. الحل: الخطوة 1: $\beta_{500} = 0.0001 + (0.02 - 0.0001) \cdot 500/1000 \approx 0.00995 + 0.0001 = 0.01005$. النتيجة: 0.01005. الربط بالذكاء الاصطناعي: تسخين الضوضاء.

مثال (41.5-8): احتمال $x_t \mid x_0$ المعطيات: $x_0 = 0$، $\bar{\alpha} = 0.5$، $x_t = 0.5$. المطلوب: $\log q(x_t \mid x_0)$ تقريباً (بُعد 1). الحل: الخطوة 1: يعني 0، تباينُ 0.5؛ $\log q = -\frac{1}{2}\log(2\pi \cdot 0.5) - \frac{0.5^2}{2 \cdot 0.5} = -0.919 - 0.25 = -1.169$. النتيجة: -1.169. الربط بالذكاء الاصطناعي: كثافة الحالة.

مثال (41.5-9): مقارنة جدولتين المعطيات: جدولة أ: $\bar{\alpha}_{100} = 0.1$؛ ب: $\bar{\alpha}_{100} = 0.3$. المطلوب: أيّ أسرع إزالة إشارة؟ الحل: الخطوة 1: أ: $1 - 0.9 = 0.1$ ضوضاء، ب: $1 - 0.7$ ⇒ أسرع إزالة في أ. النتيجة: الجدولة أ. الربط بالذكاء الاصطناعي: تحكّم بالضجيج.

مثال (41.5-10): اثنتان x_0 مختلفتان المعطيات: $x_0^{(1)} = 1, x_0^{(2)} = -1$، $\bar{\alpha} = 0.5$، $\epsilon = 0.5$. المطلوب: x_t لكلّ. الحل: الخطوة 1: $x_t^{(1)} = 0.707 \cdot 1 + \sqrt{0.5} \cdot 0.5 = 0.707 + 0.354 = 1.061$؛ $x_t^{(2)} = -0.707 + 0.354 = -0.354$. النتيجة: 1.061 و$-0.354$. الربط بالذكاء الاصطناعي: تمايز يحفظ الاتجاه.

مثال (41.5-11): المتوسّط فوق الضوضاء المعطيات: $\mathbb{E}_\epsilon[x_t]$ مع x_0 ثابت. المطلوب: القيمة. الحل: الخطوة 1: $\mathbb{E}[x_t] = \sqrt{\bar{\alpha}_t} x_0$ (الضوضاء متوسّطها 0). النتيجة: $\sqrt{\bar{\alpha}_t} x_0$. الربط بالذكاء الاصطناعي: الإشارة المتوسّطة.

مثال (41.5-12): العُمر القياسيّ σ_t المعطيات: $\bar{\alpha} = 0.3487$. المطلوب: σ_t. الحل: الخطوة 1: $\sqrt{1 - 0.3487} = \sqrt{0.6513} = 0.807$. النتيجة: 0.807. الربط بالذكاء الاصطناعي: انحراف الضجيج.

مثال (41.5-13): جدولة جيب التمام المعطيات: $\bar{\alpha}_t = \cos^2(\frac{t/T + s}{1+s} \cdot \frac{\pi}{2})$، $s = 0.008$. المطلوب: عند $t = 0$ تقريباً. الحل: الخطوة 1: $\cos^2(0) = 1 \Rightarrow \bar{\alpha}_0 \approx 1$ (لا ضوضاء ابتداءً). النتيجة: 1. الربط بالذكاء الاصطناعي: جدولة حديثة مستقرّة.

مثال (41.5-14): نسبة الإشارة للضوضاء المعطيات: $\bar{\alpha} = 0.3487$. المطلوب: $\text{SNR} = \bar{\alpha}/(1 - \bar{\alpha})$. الحل: الخطوة 1: $0.3487/0.6513 = 0.535$. النتيجة: 0.535. الربط بالذكاء الاصطناعي: مقياس الجودة.

مثال (41.5-15): خلاصة المعطيات: $x_0 = 2$، $\bar{\alpha} = 0.25$، $\epsilon = -0.5$. المطلوب: x_t. الحل: الخطوة 1: $x_t = 0.567$ $\sqrt{0.25} \cdot 2 + \sqrt{0.75} \cdot (-0.5) = 0.5 \cdot 2 + 0.866 \cdot (-0.5) = 1 - 0.433 = 0.567$. النتيجة: 0.567. الربط بالذكاء الاصطناعي: تركيب الإشارة والضجيج.

أخطاء شائعة

- **الخلط بين α_t و$\bar{\alpha}_t$:** الأول خطوة، الثاني حاصل ضرب تراكميّ.
- **نسيان الجذر في مقياس الإشارة:** $\sqrt{\bar{\alpha}_t}$ لا $\bar{\alpha}_t$.
- **الظنّ أن x_t غوسيّة شرطياً فقط:** هي كذلك بـx_0 لا ببيانات أخرى.
- **إهمال العيّنة المباشرة:** x_t يُحسب دفعةً واحدة لا خطوة بخطوة.
- **الخلط بين β_t الكبيرة والصغيرة:** الكبيرة تسرّع الضجيج لكن تُصعّب العكس.

صياغة رسمية: نُعلّم شبكة $\epsilon_\theta(x_t, t)$ تتوقّع الضجيج المضاف؛ الخسارة المبسّطة

$$L_{\text{simple}} = \mathbb{E}_{t,x_0,\epsilon}\Big[\big\|\epsilon - \epsilon_\theta(\sqrt{\bar\alpha_t}\,x_0 + \sqrt{1-\bar\alpha_t}\,\epsilon,\ t)\big\|^2\Big] \tag{5.41}$$

وخطوة العكس لإنتاج عيّنة هي

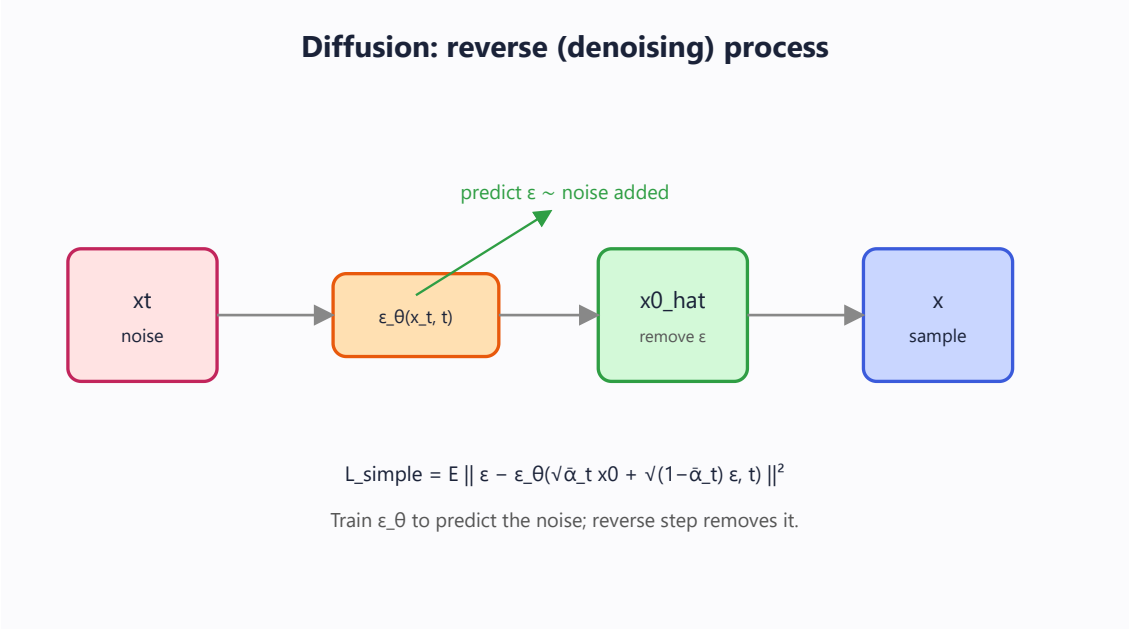
$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\Big(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar\alpha_t}}\,\epsilon_\theta(x_t,t)\Big) + \sigma_t z, \quad z\sim\mathcal{N}(0,I). \tag{6.41}$$

جدول الرموز

الرمز	المعنى
ϵ_θ	شبكة توقّع الضجيج
L_{simple}	خسارة إزالة الضجيج
σ_t	انحراف خطوة العكس

الرسم

<figure> الشكل<figcaption> 5.41: ندرّب ϵ_θ على توقّع الضجيج؛ خطوة العكس تطرحه لإنتاج



شكل ٥.٤١: *
الانتشار العكسيّ

</figure> .</figcaption>x_0

البرهان

الخطوة 1 (مطابقة السكور): تدريب إزالة الضجيج يكافئ تقدير تدرّج $\nabla \log p_t$ (score matching). ■

الخطوة 2 (تبسيط الخسارة): بإعادة كتابة KL العكسيّ، يتبقّى التنبّؤ بالضجيج ϵ فقط (Ho et al. 2020). ■

الخطوة 3 (خطوة العكس): من شرط غوسيّة $p_\theta(x_{t-1}\mid x_t)$ نستنتج (6.41) بمعامل الجدولة. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.41): خطوة عكسيةّ محسوبة المعطيات: $x_t = 0.5, \epsilon_\theta = 0.3$ (فلتكن)، $\alpha_t = 0.9, \bar{\alpha}_t = 0.3487$. المطلوب: متوسّط الخطوة العكس. الحل: الخطوة 1: $\sqrt{\alpha_t} = 0.9487$، $\sqrt{1-\bar{\alpha}_t} = 0.807$؛ المعامل $= \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} = \frac{0.1}{0.807} = 0.124$. الخطوة 2: $\mu = \frac{1}{0.9487}(0.5 - 0.124 \times 0.3) = \frac{0.5-0.037}{0.9487} = \frac{0.463}{0.9487} = 0.488$. النتيجة: $\mu \approx 0.488$. الربط بالذكاء الاصطناعي: خطوة إزالة الضجيج.

مثال (2-6.41): حساب الخسارة المعطيات: $\epsilon = 0.5$ (حقيقيّ)، $\epsilon_\theta = 0.4$ (توقّع)، بُعد 1. المطلوب: L_{simple} (للعيّنة). الحل: الخطوة 1: $(0.5 - 0.4)^2 = 0.01$. النتيجة: 0.01. الربط بالذكاء الاصطناعي: خطأ توقّع الضجيج.

مثال (3-6.41): عُمر الخطوة المعطيات: $\bar{\alpha}_t = 0.3487$. المطلوب: $\sigma_t = \sqrt{1-\bar{\alpha}_t}$. الحل: الخطوة 1: $\sqrt{0.6513} = 0.807$. النتيجة: 0.807. الربط بالذكاء الاصطناعي: ضجيج إضافيّ بالعكس.

مثال (4-6.41): بناء x_t للتدريب المعطيات: $x_0 = 1, \bar{\alpha} = 0.81, \epsilon = 0.2$. المطلوب: x_t. الحل: الخطوة 1: $x_t = \sqrt{0.81} \cdot 1 + \sqrt{0.19} \cdot 0.2 = 0.9 + 0.436 \cdot 0.2 = 0.9 + 0.087 = 0.987$. النتيجة: 0.987. الربط بالذكاء الاصطناعي: مدخل التدريب.

مثال (5-6.41): تحسّن الخسارة المعطيات: من $\epsilon_\theta = 0.4$ إلى 0.48 (أقرب لـ0.5). المطلوب: الخسارة الجديدة. الحل: الخطوة 1: $(0.5 - 0.48)^2 = 0.0004$ (انخفضت من 0.01). النتيجة: 0.0004. الربط بالذكاء الاصطناعي: تعلّم أفضل.

مثال (6-6.41): اختيار الزمن t المعطيات: نختار $t \sim \text{Uniform}\{1, \ldots, T\}$، $T = 1000$. المطلوب: احتمال $t = 500$. الحل: الخطوة 1: $1/1000 = 0.001$. النتيجة: 0.001. الربط بالذكاء الاصطناعي: تحسين الخطوة.

مثال (7-6.41): نسبة الإشارة للضوضاء في المدخل المعطيات: $\bar{\alpha} = 0.81$. المطلوب: SNR عند x_t. الحل: الخطوة 1: $\bar{\alpha}/(1-\bar{\alpha}) = 0.81/0.19 = 4.26$. النتيجة: 4.26. الربط بالذكاء الاصطناعي: جودة الإشارة.

مثال (8-6.41): جدولة التباينُ المعطيات: β_t خطّية من 10^{-4} إلى 0.02، نريد $\sigma_t^2 = 0.1$ تقريباً. المطلوب: أيّ $\bar{\alpha}$ يقابلها؟ الحل: الخطوة 1: $1 - \bar{\alpha} = 0.1 \Rightarrow \bar{\alpha} = 0.9$. النتيجة: $\bar{\alpha} = 0.9$. الربط بالذكاء الاصطناعي: ضبط الجدولة.

مثال (9-6.41): عدد الخطوات وأثره المعطيات: $T = 1000$ مقابل $T = 50$ (DDIM). المطلوب: عدّد الأثر.

الحل: الخطوة 1: T أصغر $\Rightarrow$ توليد أسرع بثمن جودة أحياناً. النتيجة: مفاضلة سرعة/جودة. الربط بالذكاء الاصطناعي: اختصار التوليد.

مثال (10-6.41): عيّنة من x_{t-1} المعطيات: $\mu = 0.488, \sigma_t = 0.2, z = 0.5$. المطلوب: x_{t-1}. الحل: الخطوة 1: $x_{t-1} = 0.488 + 0.2 \times 0.5 = 0.488 + 0.1 = 0.588$. النتيجة: 0.588. الربط بالذكاء الاصطناعي: خطوة توليد واحدة.

مثال (11-6.41): توقّع الضجيج بِبُعدين المعطيات: $\epsilon = (0.3, 0.4)$، $\epsilon_\theta = (0.1, 0.5)$. المطلوب: L_{simple}. الحل: الخطوة 1: $(0.3-0.1)^2 + (0.4-0.5)^2 = 0.04 + 0.01 = 0.05$. النتيجة: 0.05. الربط بالذكاء الاصطناعي: مجموع مربعات الأخطاء.

مثال (12-6.41): وزن الخسارة زمنيّاً المعطيات: أحياناً $L = \mathbb{E}[\lambda_t \|\epsilon - \epsilon_\theta\|^2]$. المطلوب: هل يتغيّر المُعلِم؟ الحل: الخطوة 1: بـ $\lambda_t = 1$ (Ho) نعود لـ(5.41)؛ بأوزان مختلفة نصحّح التباينُ. النتيجة: لا يتغيّر جوهريّاً. الربط بالذكاء الاصطناعي: هندسة الخسارة.

مثال (13-6.41): إعادة المعاملات المعطيات: نموذج صاخب x_{t-1} بـz. المطلوب: لماذا؟ الحل: الخطوة 1: الضجيج يحافظ على التوزيع الغوسيّ للعكس ولا يجعله حتميّاً. النتيجة: تنويع التوليد. الربط بالذكاء الاصطناعي: تفادي الانهيار.

مثال (14-6.41): دفعة تدريب المعطيات: حجم دفعة $B = 32$، متوسّط $L = 0.02$. المطلوب: الخسارة المُبلَّغة. الحل: الخطوة 1: $\mathcal{L}_{\text{batch}} = 0.02$ (متوسّط 32 عيّنة). النتيجة: 0.02. الربط بالذكاء الاصطناعي: تدرّج مستقرّ.

مثال (15-6.41): خلاصة المعطيات: $\alpha_t = 0.9, \bar{\alpha} = 0.3487, x_t = 0.7, \epsilon_\theta = 0.2$. المطلوب: μ. الحل: الخطوة 1: $0.124 \times 0.2 = 0.0248$، $(0.7 - 0.0248)/0.9487 = 0.6752/0.9487 = 0.712$. النتيجة: 0.712.

الربط بالذكاء الاصطناعي: خطوة عكس أخرى.

أخطاء شائعة

- **خلط مُعامل الجدولة:** $\frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}$ لا $\frac{1-\bar{\alpha}_t}{\sqrt{1-\alpha_t}}$.
- **نسيان جذر $\bar{\alpha}_t$ في الإشارة:** العامل $\sqrt{\bar{\alpha}_t}$ لا $\bar{\alpha}_t$.
- **الظنّ أن x_{t-1} حتميّ:** يجب إضافة $\sigma_t z$ للتنويع.
- **الخلط بين ϵ الحقيقيّ والمتوقّع:** الخسارة بينهما لا بين x_0 وx_t.
- **إهمال اختيار t موزّعاً:** التدريب يتطلّب t عشوائياً.

صياغة رسمية: نعرّف انتشاراً عشوائياً (SDE) يُضيف ضوضاءً:

$$dx = f(x,t)\,dt + g(t)\,dw, \qquad s(x,t) = \nabla_x \log p_t(x) \tag{7.41}$$

وله معادلة عكسيةّ تقابلها

$$dx = \left[f(x,t) - g(t)^2\, s(x,t)\right] dt + g(t)\, d\bar{w} \tag{8.41}$$

حيث s "السكور" يُدرّب بنمذجة مطابقة السكور.

جدول الرموز

الرمز	المعنى
$f(x,t)$	انجراف (drfit)
$g(t)$	معامل انتشار الضوضاء
$s(x,t)$	السكور $\nabla_x \log p_t$

الرسم

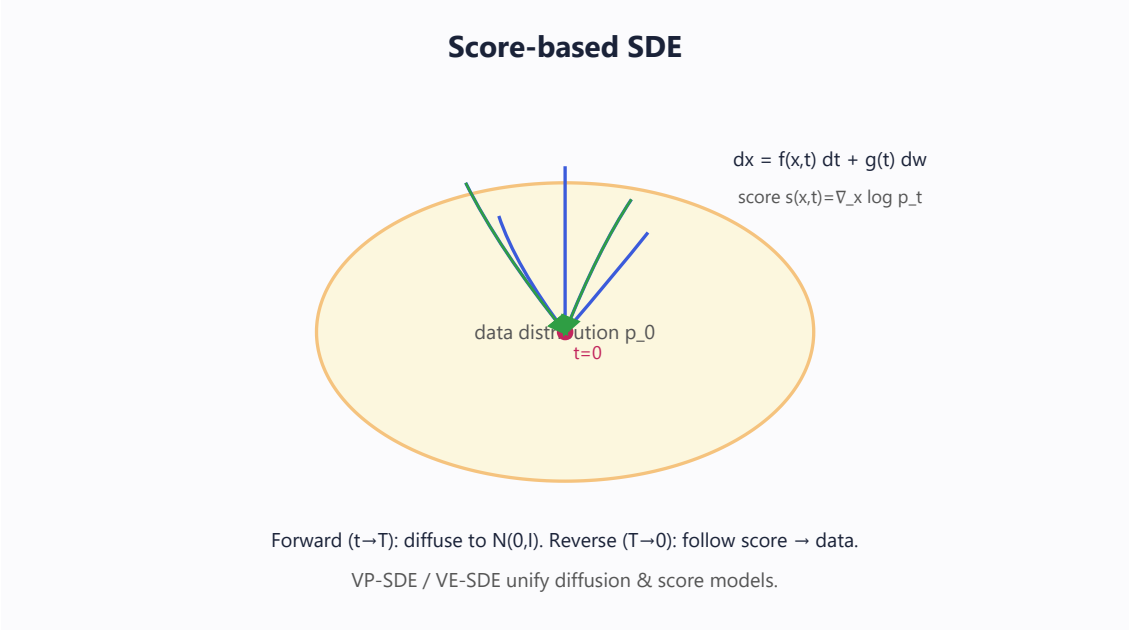
<figure> الشكل<figcaption> 6.41: المسار الأماميّ (أزرق) ينشر البيانات إلى ضجيج؛ العكس (أخضر) بقيادة السكور يعيدها بيانات.</figcaption> </figure>

البرهان

الخطوة 1 (صياغة VP): نختار $f(x,t) = -\frac{\beta(t)}{2}x$، $g(t) = \sqrt{\beta(t)}$ (انتشار تباينُ-ثابت). ■

الخطوة 2 (السكور من الغوسيّة): لتوزيع غوسيّ $s(x) = -\Sigma^{-1}(x-\mu)$ صراحةً. ■

الخطوة 3 (عكس Anderson): لمعادلة انتشار، المعادلة العكسية تحمل نفس g مع انجراف مُعدّل بالسكور (8.41). ■



شكل ٦٠٤١: *
نموذج السكور والSDE

خمسة عشر مثالاً محلولاً

مثال (1-7.41): انجراف VP عند نقطة المعطيات: $\beta(t) = 0.1$، $x = 1$. المطلوب: $f(x,t)$. الحل: الخطوة 1: $f = -0.1/2 \cdot 1 = -0.05$. النتيجة: -0.05. الربط بالذكاء الاصطناعي: سحب نحو الصفر.

مثال (2-7.41): السكور لغوسيّة قياسيّة المعطيات: $p_t = \mathcal{N}(0,1)$، $x = 2$. المطلوب: $s(x,t)$. الحل: الخطوة 1: $s(x) = -\frac{x-0}{1} = -2$. النتيجة: -2. الربط بالذكاء الاصطناعي: تدرّج اللوغاريتم.

مثال (3-7.41): سكور غوسيّ بتباين 4 المعطيات: $\sigma^2 = 4$، $x = 2$. المطلوب: $s(x)$. الحل: الخطوة 1: $s = -x/4 = -2/4 = -0.5$. النتيجة: -0.5. الربط بالذكاء الاصطناعي: تباين أكبر $\Rightarrow$ سكور أضعف.

مثال (4-7.41): توبيدي (Tweedie) المعطيات: $\mathbb{E}[x_0 \mid x_t] = \frac{1}{\sqrt{\bar\alpha_t}}(x_t + (1-\bar\alpha_t)s(x_t))$، $\bar\alpha = 0.81, x_t = 0.9, s = -1$. المطلوب: تقدير x_0. الحل: الخطوة 1: $0.9 + (1-0.81)(-1) = 0.9 - 0.19 = 0.71$؛ $0.9/0.789$. النتيجة: 0.789. الربط بالذكاء الاصطناعي: استرجاع الإشارة.

مثال (5-7.41): معامل VE-SDE المعطيات: $g(t) = \sigma^t$، $f = 0$، $\sigma = 1.1, t = 2$. المطلوب: g. الحل: الخطوة 1: $1.1^2 = 1.21$. النتيجة: 1.21. الربط بالذكاء الاصطناعي: انتشار تباين-متغيّر.

مثال (6-7.41): خسارة مطابقة السكور المعطيات: $\mathcal{L} = \mathbb{E}[\|s_\theta(x_t,t) - \nabla_{x_t}\log p_{0t}(x_t \mid x_0)\|^2]$. المطلوب: ما الذي تُقرّبه؟ الحل: الخطوة 1: الفرق بين سكور مُعلَّم والسكور الحقيقيّ (مطابقة سكور مُتسرّبة الضجيج). النتيجة: تقدير السكور. الربط بالذكاء الاصطناعي: أساس التدريب.

مثال (7-7.41): عيّنة لانجفين المعطيات: $x_{k+1} = x_k + \eta\, s(x_k) + \sqrt{2\eta}\, z$، $\eta = 0.01, s = -1$. المطلوب: تحديث من $x_k = 0.5, z = 0$. الحل: الخطوة 1: $0.5 + 0.01(-1) + 0 = 0.49$. النتيجة: $x_{k+1} = 0.49$. الربط بالذكاء الاصطناعي: مشي عشوائيّ موجّه.

مثال (8-7.41): حجم السكور المعطيات: $x = 0$ (عند الذروة). المطلوب: $s(0)$ لغوسيّة. الحل: الخطوة 1: $s(0) = -\frac{0-\mu}{\sigma^2} = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: الذروة = توازن.

مثال (9-7.41): ربط الانتشار بنموذج السكور المعطيات: ϵ_θ في (5.41) والسكور مترابطان: $s(x_t) \approx -\frac{\epsilon_\theta(x_t)}{\sqrt{1-\bar\alpha_t}}$. المطلوب: علّق. الحل: الخطوة 1: كليهما يصف نفس العملية العكسيّة من زاويتين. النتيجة: مكافئان. الربط

بالذكاء الاصطناعي: وحدة الإطار.

مثال (10-7.41): انجراف العكس المعطيات: $f = -0.05$ (من 1-7.41)، $g^2 = 0.1$، $s = -2$. المطلوب: انجراف العكس في (8.41). الحل: الخطوة 1: $f - g^2 s = -0.05 - 0.1(-2) = -0.05 + 0.2 = 0.15$. النتيجة: 0.15. الربط بالذكاء الاصطناعي: اتجاه التوليد.

مثال (11-7.41): سكور بأبعاد متعدّدة المعطيات: $x = (2, 0)$، $\mu = (0, 0)$، $\Sigma = I$. المطلوب: $s(x)$. الحل: الخطوة 1: $s = -x = -(2, 0) = (-2, 0)$. النتيجة: $(-2, 0)$. الربط بالذكاء الاصطناعي: متّجه تدرّج.

مثال (12-7.41): مقارنة VP وVE المعطيات: VP تثبّت التباينُ حول 1؛ VE تزيده. المطلوب: أيّ أصلح للبيانات عالية التباينُ؟ الحل: الخطوة 1: VE تتعامل مع تباينُ متغيّر أفضل. النتيجة: VE. الربط بالذكاء الاصطناعي: اختيار التصميم.

مثال (13-7.41): عدد خطوات لانجفين المعطيات: $\eta = 0.01$ نحتاج 1000 خطوة. المطلوب: "زمن" تقريبيّ. الحل: الخطوة 1: $10 = 0.01 \times 1000$ وحدة زمن. النتيجة: 10. الربط بالذكاء الاصطناعي: تكلفة التوليد.

مثال (14-7.41): ثبات السكور زمنيّاً المعطيات: عند $t \to T$، $p_t \approx \mathcal{N}(0, I)$، $x_T = 0.5$. المطلوب: $s(x_T)$. الحل: الخطوة 1: $s = -0.5/1 = -0.5$. النتيجة: -0.5. الربط بالذكاء الاصطناعي: سكور الضجيج الصرف.

مثال (15-7.41): خلاصة المعطيات: $\bar{\alpha} = 0.81, x_t = 0.8, s = -0.5$. المطلوب: تقدير x_0 بتويبدي. الحل: الخطوة 1: $0.8 - (0.19)(-0.5) = 0.8 - 0.095 = 0.705$، $0.705/0.9 = 0.783$. النتيجة: 0.783. الربط بالذكاء الاصطناعي: استرجاع نهائيّ.

أخطاء شائعة

- **الخلط بين f وg^2 في العكس:** الانجراف العكسيّ $f - g^2 s$ لا $f + g^2 s$.
- **إهمال إشارة السكور:** s سالب غالباً (يسحب نحو الذروة).
- **الظنّ أن VP=VE:** مختلفان في f, g.
- **الخلط بين السكور والضجيج:** علاقتهما عبر العامل $\sqrt{1 - \bar{\alpha}_t}$ لا مطابقة مباشرة.
- **إهمال خطوة لانجفين:** التوليد يحتاج مشياً متكرّراً.

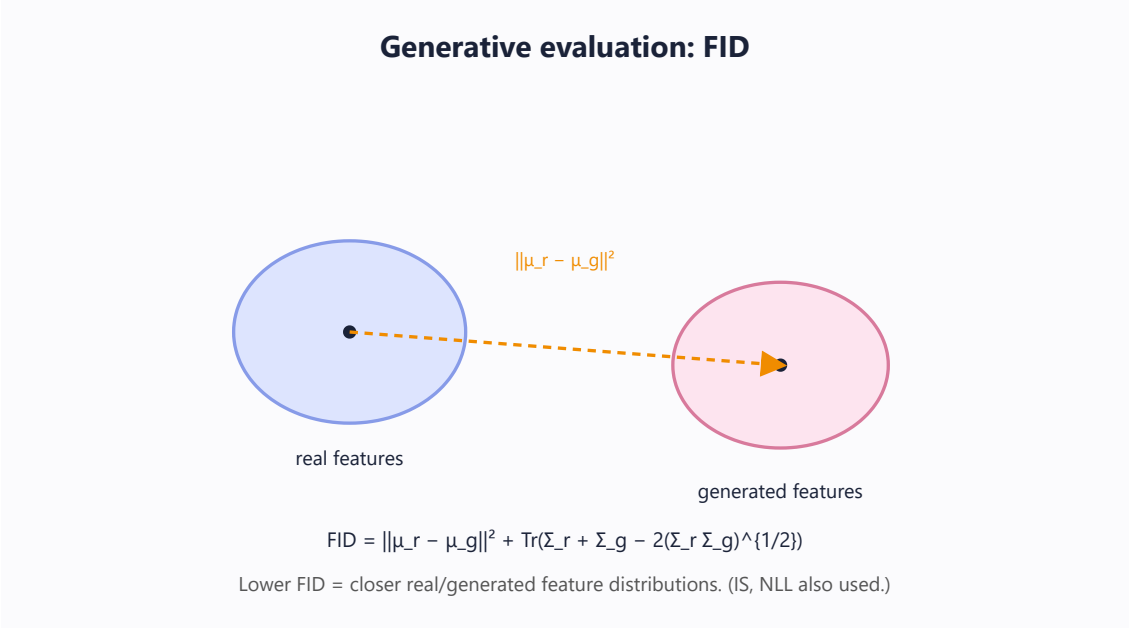
صياغة رسمية: تُقارن مسافة Fréchet للتوليد (FID) توزيعيّ الميزات (الحقيقيّ والناتج) بوصفهما غوسيّيْن:

$$\mathrm{FID} = \|\mu_r - \mu_g\|^2 + \mathrm{Tr}\big(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}\big) \tag{9.41}$$

وحاصل الابتكار $\mathrm{IS} = \exp\big(\mathbb{E}_x \, \mathrm{KL}(p(y \mid x) \| p(y))\big)$ يقيس الجودة والتنوّع.

جدول الرموز

الرمز	المعنى
μ_r, μ_g	وسوط الميزات (حقيقيّ/ناتج)
Σ	مصفوفة التغاير للميزات
IS	حاصل الابتكار



شكل ٧٠٤١: *
قياس جودة التوليد

الرسم

<figure> الشكل<figcaption> 7.41: FID يقيس المسافة بين غوسيّتي الميزات، الأصغر أقرب للواقع.</figcaption>
</figure>

البرهان

الخطوة 1 (افتراض غوسيّ): ميزات Inception لتوزيعيّ البيانات تُقرّب $\mathcal{N}(\mu, \Sigma)$ ⇒ Fréchet = (9.41). ■

الخطوة 2 (IS): $p(y \mid x)$ حادّ (جودة) و$p(y)$ متّسع (تنوّع) ⇒ KL كبير ⇒ IS كبير. ■

الخطوة 3 (NLL): للنماذج ذات الاحتمال الصريح نُقدّر $\log p(x)$ بأخذ عيّنات مهمّة. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.41): إزاحة الوسط فقط المعطيات: $\mu_r = (0,0), \mu_g = (1,0)$، $\Sigma_r = \Sigma_g = I$. المطلوب: FID. الحل: الخطوة 1: $\|\Delta\mu\|^2 = 1$؛ الحدّ الثاني $\mathrm{Tr}(I + I - 2I) = 0 \Rightarrow$ FID $= 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: عقوبة الإزاحة.

مثال (2-8.41): تغاير مختلف المعطيات: μ متطابقان، $\Sigma_r = I, \Sigma_g = 2I$ (بُعد 2). المطلوب: FID. الحل: الخطوة 1: $\|\Delta\mu\|^2 = 0$؛ $\mathrm{Tr}(I + 2I - 2\sqrt{I \cdot 2I}) = \mathrm{Tr}(3I - 2\sqrt{2}\, I) = 3 - 2.828 = 0.172$. النتيجة: 0.172. الربط بالذكاء الاصطناعي: عقوبة التباين.

مثال (3-8.41): كلاهما مختلف المعطيات: $\mu_g = (1,0)$، $\Sigma_g = 2I$ (مع $\mu_r, \Sigma_r = I$ من 1-8.41). المطلوب: FID كلّي. الحل: الخطوة 1: $1.172 = 1 + 0.172$. النتيجة: 1.172. الربط بالذكاء الاصطناعي: مجموع العقوبتين.

مثال (4-8.41): تطابق تامّ المعطيات: التوزيعان متطابقان. المطلوب: FID. الحل: الخطوة 1: $\mu_r = \mu_g$، $\Sigma_r = \Sigma_g \Rightarrow$ كلّ الحدود صفر. النتيجة: 0. الربط بالذكاء الاصطناعي: مثاليّ.

مثال (5-8.41): إزاحة أكبر المعطيات: $\mu_g = (2,0)$، تغايرات متطابقة. المطلوب: FID. الحل: الخطوة 1:

$\|\Delta\mu\|^2 = 4$؛ حدّ التغاير $0 \Rightarrow 4$. النتيجة: 4. الربط بالذكاء الاصطناعي: FID حسّاس للإزاحة.

مثال (41.8-6): حساب IS مثاليّ المعطيات: $p(y \mid x)$ دلتا عند صنف، $p(y)$ منتظمة على $K = 1000$ صنف. المطلوب: IS. الحل: الخطوة 1: $\mathrm{KL} = \log 1000$؛ $\mathrm{IS} = \exp(\log 1000) = 1000$. النتيجة: 1000. الربط بالذكاء الاصطناعي: تنوّع كامل + جودة.

مثال (41.8-7): IS أضعف المعطيات: $\mathrm{KL} = 2$. المطلوب: IS. الحل: الخطوة 1: $e^2 = 7.389$. النتيجة: 7.39. الربط بالذكاء الاصطناعي: جودة منخفضة.

مثال (41.8-8): NLL لكلّ بُعد المعطيات: -120 $= \log p(x)$، بُعد x هو 3. المطلوب: بُعد/NLL. الحل: الخطوة 1: $-120/3 = -40$ (وحدة نات) — رقم توضيحيّ. النتيجة: -40 نات/بُعد. الربط بالذكاء الاصطناعي: قياس الكثافة.

مثال (41.8-9): مقارنة نموذجين المعطيات: نموذج أ، FID=5 نموذج ب، FID=10. المطلوب: أيّ أفضل؟ الحل: الخطوة 1: الأقلّ FID أقرب للواقع $\Rightarrow$ النموذج أ. النتيجة: أ. الربط بالذكاء الاصطناعي: FID تنازليّ جودة.

مثال (41.8-10): أبعاد الميزات المعطيات: Inception تُنتج 2048 ميزة. المطلوب: بُعد Σ. الحل: الخطوة 1: 2048×2048 (تُخفّض عمليّاً بافتراض قُطريّ). النتيجة: 2048. الربط بالذكاء الاصطناعي: حساب FID مكلف.

مثال (41.8-11): الدقّة مقابل الاستدعاء المعطيات: نموذج جيّد الصور لكن مكرّر. المطلوب: ما الذي يُظهره IS وحده؟ الحل: الخطوة 1: IS قد يكون مرتفعاً رغم ضعف التنوّع (لا يكشف الانهيار وحده). النتيجة: IS محدود. الربط بالذكاء الاصطناعي: حاجة لـFID.

مثال (41.8-12): KID بديل المعطيات: ICD kernel يتجنّب افتراض غوسيّ. المطلوب: متى نفضّله؟ الحل: الخطوة 1: مع عيّنات قليلة حيث تقدير FID غير مستقرّ. النتيجة: عيّنات صغيرة. الربط بالذكاء الاصطناعي: بديل robust.

مثال (41.8-13): تغاير قُطريّ المعطيات: $\Sigma_r = \mathrm{diag}(1,1), \Sigma_g = \mathrm{diag}(2,2)$ (بُعد 2، وسطان متطابقان). المطلوب: FID. الحل: الخطوة 1: الحدّ $= 2 \times 0.172 = 2 \times (3 - 2.828) = (1+2-2\sqrt{2}) + (1+2-2\sqrt{2}) =$ 0.344. النتيجة: 0.344. الربط بالذكاء الاصطناعي: يحترم الأبعاد.

مثال (41.8-14): أثر حجم العيّنة المعطيات: FID يُقدّر بـ50000 عيّنة أفضل من 1000. المطلوب: لماذا؟ الحل: الخطوة 1: تقدير μ, Σ يتطلّب عيّنات كافية لتفادي التحيّز. النتيجة: استقرار التقدير. الربط بالذكاء الاصطناعي: بروتوكول التقييم.

مثال (41.8-15): خلاصة المعطيات: $\mu_r = (0,0), \mu_g = (0.5, 0.5), \Sigma_r = \Sigma_g = I$. المطلوب: FID. الحل: الخطوة 1: $\|\Delta\mu\|^2 = 0.5^2 + 0.5^2 = 0.5$؛ حدّ التغاير $0 \Rightarrow 0.5$. النتيجة: 0.5. الربط بالذكاء الاصطناعي: مقياس شامل.

أخطاء شائعة

- **الظنّ أن FID=0 دائماً ممكن:** يتطلّب تطابق التوزيعين تماماً.
- **الخلط بين اتجاه FID وIS:** FID أصغر=أفضل؛ IS أكبر=أفضل.
- **نسيان حدّ التغاير:** FID ليس فقط فرق الوسوط.
- **الاعتماد على IS وحده:** لا يكشف انهيار النمط.
- **إهمال حجم العيّنة:** FID غير مستقرّ مع عيّنات قليلة.

جدول تجميع النظريات

النظرية	العنوان	المعادلة المحوريّة	الرسم
2.41	VAEJ ELBO	$\log p(x) \geq \mathbb{E}_q[\log p(x \mid z)] - \mathrm{KL}$	fig-4101
3.41	GAN لعبة	$\min_G \max_D V(D,G)$	fig-4102
4.41	التدفّقات التطبيعيّة	$p_X = p_Z(f^{-1}) \lvert \det J_{f^{-1}} \rvert$	fig-4103
5.41	الانتشار الأماميّ	$q(x_t \mid x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)$	fig-4104
6.41	الانتشار العكسي	$L_{\text{simple}} = \mathbb{E}\lVert\epsilon - \epsilon_\theta\rVert^2$	fig-4105
7.41	نموذج السكور/SDE	$dx = f dt + g dw,\ s = \nabla \log p_t$	fig-4106
8.41	قياس الجودة	$\mathrm{FID} = \lVert\mu_r - \mu_g\rVert^2 + \mathrm{Tr}(\dots)$	fig-4107

عشرون تمريناً محلولاً (إجابات موجزة)

١. **(ELBO)** إعادة بناء -1.0، $\mathrm{KL} = 0.3$ — $\mathcal{L} = -1.3$.

٢. **(KL غوسيّ)** $\mu = 0, \sigma = 1.5, d = 1$ — $\dots = -0.405 + 0.225 \Rightarrow \mathrm{KL} = 0.220$.

٣. **(VAE-β)** $\beta = 2, \mathrm{KL} = 0.4$ — عقوبة 0.8.

٤. **(GAN)** $p_d = 0.6, p_g = 0.4$ — $D^* = 0.6$.

٥. **(GAN قيمة)** $\mathrm{JSD} = 0.2$ — $V = -1.386 + 0.4 = -0.986$.

٦. **(تدفّق)** $f(z) = 3z$ — العامل $1/3$.

٧. **(تدفّق 2D)** $\mathrm{diag}(2,2)$ — العامل $1/4$.

٨. **(تدفّق لوغ)** $\log p_Z = -1, \log\lvert\det J\rvert = 1.1$ — $\log p_X = -2.1$.

٩. **(انتشار)** $\beta = 0.1, t = 10$ — $\bar{\alpha} = 0.3487, \sqrt{\bar{\alpha}} = 0.5905$.

١٠. **(انتشار)** $\bar{\alpha} = 0.3487$ — $\sigma_t = 0.807$.

١١. **(عيّنة)** $x_0 = 1, \bar{\alpha} = 0.5, \epsilon = 0$ — $x_t = 0.707$.

١٢. **(عكس)** $\alpha = 0.9, \bar{\alpha} = 0.3487, x_t = 0.5, \epsilon_\theta = 0.3$ — $\mu = 0.488$.

١٣. **(خسارة)** $\epsilon = 0.5, \epsilon_\theta = 0.4$ — $L = 0.01$.

١٤. **(سكور)** $\sigma = 1, x = 2$ — $s = -2$.

١٥. **(توييدي)** $\bar{\alpha} = 0.81, x_t = 0.9, s = -1$ — $\mathbb{E}[x_0] = 0.789$.

١٦. **(FID وسط)** $\mu_r = (0,0), \mu_g = (1,0)$ — $\lVert\Delta\mu\rVert^2 = 1$.

١٧. **(FID تغاير)** $\Sigma_r = I, \Sigma_g = 2I$ — 0.172.

١٨. **(FID كلّي)** الاثنان معاً — 1.172.

١٩. **(IS)** $K = 1000$ دلتا — $\mathrm{IS} = 1000$.

٢٠. **(خلاصة)** $\mu_g = (0.5, 0.5), I$ — $\mathrm{FID} = 0.5$.

فهرس الرموز

الرمز	المعنى	أول ورود
$\mathcal{L}$	الحدّ السفليّ للدليل	2.41
D, G	المُميّز/المولّد	3.41
f	تحويل التدفّق	4.41
$\bar{\alpha}_t$	حاصل إشارات الانتشار	5.41
ϵ_θ	شبكة الضجيج	6.41
$s(x,t)$	السكور	7.41
FID	مسافة Fréchet	8.41

المراجع

- Kingma, D., Welling, M. (2014). *Auto-Encoding Variational Bayes*. ICLR.
- Goodfellow, I. et al. (2014). *Generative Adversarial Networks*. NeurIPS.
- Rezende, D., Mohamed, S. (2015). *Variational Inference with Normalizing Flows*. ICML.
- Ho, J., Jain, A., Abbeel, P. (2020). *Denoising Diffusion Probabilistic Models*. NeurIPS.
- Song, Y., Ermon, S. (2019). *Generative Modeling by Estimating Gradients of the Data Distribution*. ICLR.
- Heusel, M. et al. (2017). *GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium*. NeurIPS.

النقل الأمثل والمسافات المائية Transport (Optimal & Wasserstein)

«بدل مقارنة توزيعين نقطةً بنقطة، نسألندر بأيّ كلفة ننقل كتلة أحدهما ليصبح الآخر، هذا هو جوهر النقل الأمثل.»

عندما تتداخل توزيعان تداخل بسيط أو لا تتداخل أصلاً، تفشل كثير من المسافات الكلاسيكية في مقارنتهما بينما تفتقد المنحنيات الطبيعية للنسبة المؤدّية نحو البيانات. النقل الأمثل (OT) يوفّر مسافات هندسية جوهرية (Wasserstein) تبقى ذات معنى حتى للتوزيعات المنفصلة، وهي الأساس الرياضي لـ GAN Wasserstein و الانتظام الإنتروبي و تدفّقات التدرّج.

سبع نظريات:

- **2.42 صياغة كانتوروفيتش** — $\mathrm{OT}_c(p,q) = \min_{\gamma \in \Pi(p,q)} \int c(x,y)\, d\gamma(x,y)$.
- **3.42 ثنائية كانتوروفيتش-روبنشتاين (W1)** — $W_1(p,q) = \sup_{\|f\|_{\mathrm{Lip}} \le 1} \mathbb{E}_p[f] - \mathbb{E}_q[f]$.
- **4.42 الانتظام الإنتروبي وSinkhorn** — $\min_{\gamma} \langle C, \gamma \rangle + \varepsilon\, H(\gamma)$.
- **5.42 WGAN والناقد Lipschitz** — $\min_G \max_{\|f\|_L \le 1} \mathbb{E}_{p_{data}}[f] - \mathbb{E}_{p_g}[f]$.
- **6.42 مسافة W2 وخريطة Brenier** — $W_2^2 = \min_{\#(p,T)=q} \int \|x - T(x)\|^2 dp$ مع $T = \nabla \psi$.
- **7.42 تدفّق التدرّج JKO** — $\rho_{n+1} = \arg\min_{\rho} \frac{1}{2\tau} W_2^2(\rho, \rho_n) + \mathcal{F}(\rho)$.
- **8.42 تباعد Sinkhorn العمليّ** — $S_\varepsilon(p,q) = W_\varepsilon(p,q) - \frac{1}{2} W_\varepsilon(p,p) - \frac{1}{2} W_\varepsilon(q,q)$.

كلّ نظرية تتبع القالب: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
γ	خطة النقل (coupling)	$\gamma \in \Pi(p,q)$
$c(x,y)$	دالة الكلفة	غالباً $\|x-y\|^2$
W_k	مسافة واسرشتاين	$k = 1, 2$
ε	معامل الانتظام الإنتروبي	Sinkhorn
ψ	دالّة محدّبة (Brenier)	$T = \nabla \psi$
τ	خطوة الزمن (JKO)	

الاتفاقيات: الكتل منسوبة إلى قيمتها 1، المسافات على الكلفة $\|x-y\|^2$ افتراضياً، كلّ المعادلات في كتل LTR.

صياغة رسمية: لقياسين احتماليّين p, q وكلفة نقل $c(p,q)$، فإنّ النقل الأمثل هو

$$\mathrm{OT}_c(p,q) = \min_{\gamma \in \Pi(p,q)} \int c(x,y)\, d\gamma(x,y) \tag{1.42}$$

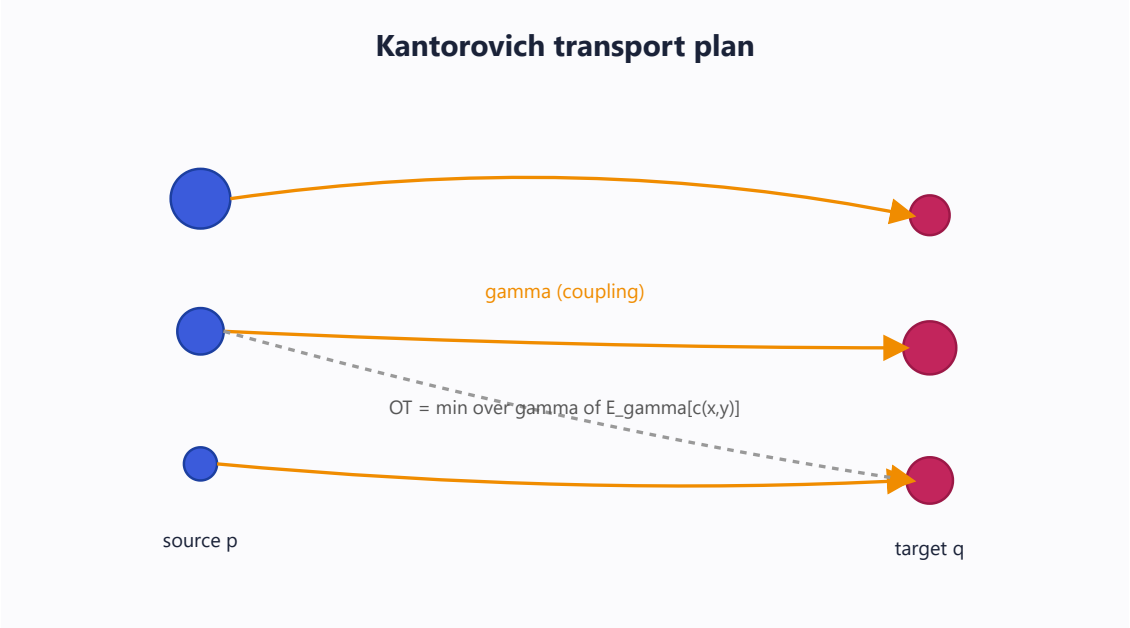
حيث $\Pi(p,q)$ مجموعة "الانسحابات" (couplings) التي يكون عندها الهامش (العمود) γ هو p والعمود الثاني هو q.

جدول الرموز

الرمز	المعنى
$\gamma(x, y)$	كتلة منقولة من x إلى y
$\Pi(p, q)$	مجموعة الانسحابات ذات الهوامش p, q
OT_c	كلفة النقل الأمثل

الرسم

<figure> الشكل<figcaption> 1.42: خطة النقل γ تُقرّر كمّ "الكتلة" منقولة من كلّ مصدر إلى كلّ هدف بأقلّ



شكل ١٠٤٢: *
صياغة كانتوروفيتش

كلفة.<figcaption/> </figure>

البرهان

الخطوة 1 (وجود الحلّ): $\Pi(p, q)$ مجموعة محدودة البعد وحسب انخفاض الكلفة، هناك حركة كتلة تدعم γ بشرط الهامشين. ■

الخطوة 2 (برنامج خطّي): المُتغيّر γ خطّيّ في قيدين خطّيين (الهامشان) ومُعاداة خطّية $\Rightarrow$ برنامج خطّيّ تقنيّ الأنواع. ■

الخطوة 3 (الحلّ الأمثل): حركة الكتلة تقريبياً "توضّع" الكلفة، وإن كان $\gamma^\star$ هو الحلّ فإنّ $\mathrm{OT}_c(p, q) = \int c\, d\gamma^\star$. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.42): هويّة 2×2 المعطيات: $p = q = (1/2, 1/2)$، $C = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$. المطلوب: min و$\gamma^\star$. الحل: الخطوة 1: $\gamma_{11} = t \Rightarrow \gamma_{12} = 1/2 - t, \gamma_{21} = 1/2 - t, \gamma_{22} = t$؛ الهدف $= 1 - 2t$. الخطوة 2: أقلّه عند $t = 1/2 \Rightarrow$ $\gamma^\star = \begin{bmatrix} 1/2 & 0 \\ 0 & 1/2 \end{bmatrix}$. النتيجة: $\mathrm{OT} = 0$. الربط بالذكاء الاصطناعي: هوية $\Rightarrow$ لا نقل.

مثال (2-2.42): تبديل كلفة المعطيات: نفس p, q لكن $C = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$. المطلوب: OT. الحل: الخطوة 1: الهدف $2t =$؛ أقلّه عند $t = 0 \Rightarrow \gamma^\star = \begin{bmatrix} 0 & 1/2 \\ 1/2 & 0 \end{bmatrix}$. النتيجة: $\text{OT} = 0$. الربط بالذكاء الاصطناعي: نطابق بالنقل الصحيح.

مثال (3-2.42): كلفة عالية للتبديل المعطيات: $p = q = (1/2, 1/2)$، $C = \begin{bmatrix} 0 & 10 \\ 10 & 0 \end{bmatrix}$. المطلوب: OT. الحل: الخطوة 1: الهدف $10(1 - 2t) =$؛ أقلّه 0 عند $t = 1/2$. النتيجة: $\text{OT} = 0$ (نتجنّب الكلفة العالية). الربط بالذكاء الاصطناعي: حركة الرموز الرخيصة.

مثال (4-2.42): كتل غير متساوية المعطيات: $p = (0.6, 0.4)$، $q = (0.4, 0.6)$، C هويّة (من 1-2.42). المطلوب: OT. الحل: الخطوة 1: الهدف $1.0 - 2t =$، $t \in [0, 0.4]$؛ أقلّ عند $t = 0.4$. الخطوة 2: $\gamma^\star =$ $\begin{bmatrix} 0.4 & 0.2 \\ 0 & 0.4 \end{bmatrix}$؛ $\text{OT} = 0.2$. النتيجة: 0.2. الربط بالذكاء الاصطناعي: يُناسب فرق الكتل.

مثال (5-2.42): 1D مسافة واسرشتاين-1 المعطيات: $p = (1/2, 1/2)$ على $\{0, 1\}$، $q = (1/2, 1/2)$ على $\{1, 2\}$. المطلوب: W_1. الحل: الخطوة 1: q هو p مُزاحاً بواسطة 1 في كلّ كتلة. الخطوة 2: رمز $W_1 = \frac{1}{2}|0 - 1| +$ $\frac{1}{2}|1 - 2| = 1$. النتيجة: $W_1 = 1$. الربط بالذكاء الاصطناعي: مسافة الترجمة.

مثال (6-2.42): تبداء الوسط المعطيات: p على $\{0, 1\}$، q على $\{0, 2\}$، كلّ منها $(1/2, 1/2)$. المطلوب: W_1. الحل: الخطوة 1: كميات: $0.5 = |2 - 1|\frac{1}{2} + |0 - 0|\frac{1}{2}$. النتيجة: $W_1 = 0.5$. الربط بالذكاء الاصطناعي: نصف تباعد نقاط.

مثال (7-2.42): منطقة بين دوالّ التوزيع المعطيات: مثال (6-2.42). المطلوب: $W_1 = \int |F_p - F_q| dx$. الحل: الخطوة 1: الفرق غير صفريّة على $[1, 2)$ بقيمة $0.5 = 1 - 0.5$، طولها 1. الخطوة 2: المساحة $0.5 \cdot 1 =$. النتيجة: 0.5 (يتّفق). الربط بالذكاء الاصطناعي: تعريف بديل 1D.

مثال (8-2.42): مصفوفة كلفة 3×3 المعطيات: $p = q = (1/3, 1/3, 1/3)$ على خطّ $0, 1, 2$، $c(i, j) = |i - j|$. المطلوب: OT الأمثل. الحل: الخطوة 1: بهوية المطابقة $\gamma_{ii} = 1/3$ كلفتها 0. النتيجة: $\text{OT} = 0$. الربط بالذكاء الاصطناعي: النقل إلى نفس الموقع.

مثال (9-2.42): قيد الكتلة المعطيات: إجمالي الكتل. المطلوب: التحقّق من $\gamma^\star$ في (1-2.42). الحل: الخطوة 1: صفوف: $0.5 + 0 = 0.5$، $0.5 + 0 = 0.5$؛ أعمدة: $0.5, 0.5$. النتيجة: تحقّق الهامش. الربط بالذكاء الاصطناعي: شرط الانسحاب.

مثال (10-2.42): درجات الحرية المعطيات: مصفوفة $a \times b$. المطلوب: بعد فضاء Π. الحل: الخطوة 1: $(a - 1)(b - 1)$؛ لـ $2 \times 2 = 1$ (متغيّر واحد t). النتيجة: 1. الربط بالذكاء الاصطناعي: لُغز خطّيّ.

مثال (11-2.42): إعادة التطبيع المعطيات: كتلّ بلا إجمالي 1، $p = (2, 2), q = (1, 3)$. المطلوب: OT بعد التطبيع. الحل: الخطوة 1: $\tilde{p} = (1/2, 1/2)$، $\tilde{q} = (1/4, 3/4)$؛ نطبّق البرنامج الخطّي المعتاد. النتيجة: يعطي OT قياسيّاً. الربط بالذكاء الاصطناعي: القياسيّة ضروريّة.

مثال (12-2.42): OT كمتر (متناظر) المعطيات: $\text{OT}(q, p) = \text{OT}(p, q)$ لـ $c(x, y) = c(y, x)$. المطلوب: تحقّق سريع. الحل: الخطوة 1: تبديل الهامشين يُبدّل $\gamma^\top$؛ الكلفة متماثلة $\Rightarrow$ OT متماثل. النتيجة: متماثل. الربط بالذكاء الاصطناعي: مسافة قياسيّة.

مثال (13-2.42): EMD كهدف الأرض المعطيات: توزيعان منفصلان كتلةً. المطلوب: لماذا EMD أفضل من TV؟ الحل: الخطوة 1: TV = مجموع الكتل المنقولة الواجب تكبّدها؛ EMD يضيف البُعد. النتيجة: EMD يحفظ الهندسة. الربط بالذكاء الاصطناعي: أساس OT.

مثال (14-2.42): مثال قُطريّ المعطيات: p على x_1 فقط، q على y_1 فقط (نقطتين)، $c = \|x_1 - y_1\|$. المطلوب: OT. الحل: الخطوة 1: كلّ كتلة 1 تنتقل $\text{OT} = c(x_1, y_1) \Rightarrow$. النتيجة: $c(x_1, y_1)$. الربط بالذكاء الاصطناعي: أبعد

حالة.

مثال (15-2.42): خلاصة المعطيات: $p = q = (1/3, 2/3)$، C هويّة. المطلوب: OT (نتوقّع 0). الحل: الخطوة 1: بهوية المطابقة $\gamma_{11} = 1/3, \gamma_{22} = 2/3 \Rightarrow$ كلفة 0. النتيجة: 0. الربط بالذكاء الاصطناعي: ثبات الهوية.

أخطاء شائعة

- **الخلط بين $\Pi(p,q)$ والجداء الخارجيّ:** Π مجموعة كلّ الانسحابات لا $\mu \otimes \nu$ فقط.
- **نسيان قيد الهامش:** الحلّ بلا قيدي صفوف/أعمدة ليس خطة نقل.
- **ظنّ أن النقل كلفته عدديّ خطّي:** البرنامج خطّيّ بمتغيّر γ.
- **إهمال تطبيع الكتل:** بلا كتلَ مجموعها 1 لا توزيع.
- **الخلط بين OT وTV:** OT يعكس البُعد (transport cost) لا مجرّد فرق.

صياغة رسمية: لمسافة كلفة المشتقّ المطلق $c(x,y) = \|x - y\|$، تعطي ثنائية KR المسافة المائية-الأولى كحدّ أقصى للفروق المُتوقّعة:

$$W_1(p,q) = \sup_{\|f\|_{\text{Lip}} \le 1} \big(\mathbb{E}_p[f] - \mathbb{E}_q[f]\big) \tag{2.42}$$

جدول الرموز

الرمز	المعنى
$\|f\|_{\text{Lip}}$	ثابت ليبنتس لـf
W_1	مسافة واسرشتاين-1

الرسم

<figure> الشكل<figcaption> 2.42: نبحث عن دالّة f بثابت ليبنتس ≤ 1 تزيد الفرق بين تسجيليّ الإشارة.</figcaption> </figure>

البرهان

الخطوة 1 (الثنويّة الضعيفة): $\int c\,d\gamma \ge \int (f+g)\,d\gamma = \mathbb{E}_p[f] + \mathbb{E}_q[g]$ لكلّ $f(x) + g(y) \le c(x,y) \Rightarrow$ حدّ أدنى. ■

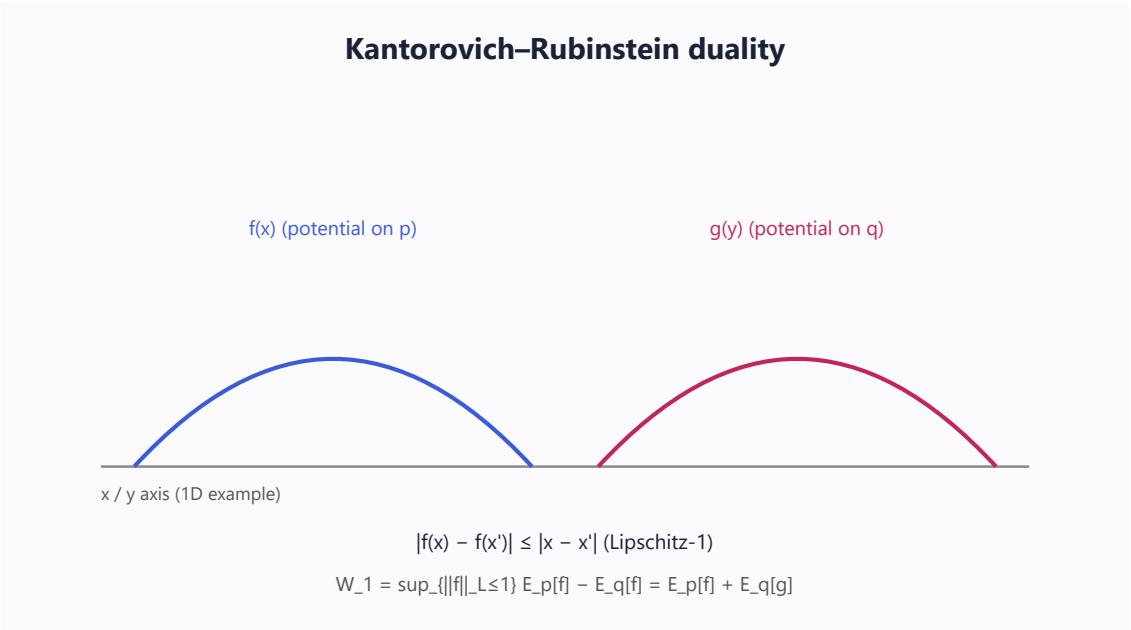
الخطوة 2 (ثنويّة قويّة): ببرنامج خطّيّ ذي شبه-متقطّع، تتساوى القيمتان؛ أي sup = min. ■

الخطوة 3 (صياغة 1-Lip): لـ$c = \|x - y\|$ نضع $g = -f$ مع $\|f\|_{\text{Lip}} \le 1 \Rightarrow$ (2.42). ■

خمسة عشر مثالاً محلولاً

مثال (1-3.42): f هي الهويّة المعطيات: $f(x) = x$، p, q كما في (5-2.42). المطلوب: $\mathbb{E}_p[f] - \mathbb{E}_q[f]$. الحل: الخطوة 1: $\mathbb{E}_p[f] = 0.5 \cdot 0 + 0.5 \cdot 1 = 0.5$؛ $\mathbb{E}_q[f] = 0.5 \cdot 1 + 0.5 \cdot 2 = 1.5$. الخطوة 2: الفرق $0.5 - 1.5 = -1$. النتيجة: -1 (نأخذ قيمة مطلقة بـ$-f$). الربط بالذكاء الاصطناعي: الاتجاه القياسيّ.

مثال (2-3.42): عكس الإشارة المعطيات: $\tilde{f} = -x$ (ثابت ليبنتس 1). المطلوب: القيمة المثلى. الحل: الخطوة 1: $\mathbb{E}_p[-x] - E_q[-x] = -0.5 - (-1.5) = 1$. النتيجة: $W_1 = 1$ (يتّافق مع 5-2.42). الربط بالذكاء الاصطناعي: الثنويّة تصطاد الأدنى.



شكل ٢٠٤٢: *
ثنائية KR

مثال (3-3.42): ثابت ليبنتس لـ $f(x) = x$ المعطيات: $|f(b) - f(a)| = |b - a|$. المطلوب: تحقّق $\|f\|_{\text{Lip}} \leq 1$. الحل: الخطوة 1: $\|f\|_{\text{Lip}} = 1 \Rightarrow$ داخل المجموعة. النتيجة: نعم. الربط بالذكاء الاصطناعي: دالّة مسموحة.

مثال (4-3.42): دالّة مرفوضة المعطيات: $f(x) = 2x$. المطلوب: $\|f\|_{\text{Lip}}$. الحل: الخطوة 1: $|2b-2a| = 2|b-a|$. النتيجة: $\|f\|_{\text{Lip}} = 2 > 1 \Rightarrow$ مُستبعدة من الحدّ. الربط بالذكاء الاصطناعي: قيد اللّيبنتس ملزم.

مثال (5-3.42): إزاحة ثابتة المعطيات: $f(x) = c$ (ثابت). المطلوب: القيمة. الحل: الخطوة 1: $\mathbb{E}_p[c] - \mathbb{E}_q[c] = c - c = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: الثوابت لا تُسهم.

مثال (6-3.42): مثال (6-2.42) بالثنويّة المعطيات: $f(x) = -x$، p على $\{0, 1\}$، q على $\{0, 2\}$. المطلوب: W_1. الحل: الخطوة 1: $\mathbb{E}_p[-x] = -0.5$؛ $\mathbb{E}_q[-x] = \frac{1}{2}(0) + \frac{1}{2}(-2) = -1$. الخطوة 2: الفرق $-0.5 - (-1) = 0.5$. النتيجة: 0.5 (يتّافق). الربط بالذكاء الاصطناعي: الثنويّة تعمل 1D.

مثال (7-3.42): فرق متوسّطات المعطيات: $p = (0.5, 0.5)$ على $\{0, 1\}$، q على $\{1, 2\}$. المطلوب: $\mathbb{E}_p[x] - \mathbb{E}_q[x]$. الحل: الخطوة 1: $0.5 - 1.5 = -1$؛ بـ$f = -x$ نحصل $W_1 = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: فرق الوسائط.

مثال (8-3.42): إشارة الوضع المثالي المعطيات: كثابت ليبنتس 1، أقصى فرق على اليسار يمين. المطلوب: كيف يُنتقى sign؟ الحل: الخطوة 1: نختار الإشارة (عبر $\pm f$) بحيث يكون الفرق موجباً. النتيجة: القيمة المطلقة. الربط بالذكاء الاصطناعي: الحلّ يعرف الاتجاه.

مثال (9-3.42): g كثابت ليبنتس سالب المعطيات: $f(x) + g(y) \leq c(x, y)$. المطلوب: أدنى قيمة ممكنة. الحل: الخطوة 1: يمكن أن تكون سالبة (with $g = -f$). القيد يتحقّق لتوزيعات موزونة. النتيجة: غير مقيّدة بأعلى. الربط بالذكاء الاصطناعي: حرّية الإشارة.

مثال (10-3.42): حدود ثنويّة المعطيات: هل الثنويّة = صياغة كانتوروفيتش (1-2.42)؟ المطلوب: علّق. الحل: الخطوة 1: نعم، بقيمتين تتساويان (ثنويّة قويّة). النتيجة: متكافئتان. الربط بالذكاء الاصطناعي: صياغتان لنفس المسافة.

مثال (11-3.42): حدود العمليّة المعطيات: نريد ناقداً تقريبيّاً (شبكة). المطلوب: ماذا يقارب؟ الحل: الخطوة 1: يقارب الدالّة المثلى 1-Lip (ناقد WGAN). النتيجة: ناقد مفيد. الربط بالذكاء الاصطناعي: أساس WGAN.

مثال (12-3.42): مثال 2D المعطيات: p, q على مستوى، $f(x,y) = x$ (جزئيّ). المطلوب: ثابت ليبنتس. الحل: الخطوة 1: $\|f\|_{\text{Lip}} = 1$ (مشتقّة جزئيّة: $\partial f/\partial x = 1$، $\partial f/\partial y = 0$، المعيار ≤ 1). النتيجة: مسموحة. الربط بالذكاء الاصطناعي: تعميم 2D.

مثال (13-3.42): يأتي EMD بالتساوي المعطيات: في 1D، W_1 = المسافة بين مراكز الكتلة (توزيعات نقطتين). المطلوب: تحقّق. الحل: الخطوة 1: $W_1 = \int |F_p - F_q| = |\mu_p - \mu_q|$ لتوزيعات نقطة واحدة. النتيجة: فرق مركزيّ. الربط بالذكاء الاصطناعي: يُبسّط 1D.

مثال (14-3.42): ثبات اللّيبنتس المعطيات: f بثابت ليبنتس ≤ 1 يمكن ضربه بـ$\rho \in [-1,1]$ preserving. المطلوب: علّق على المجموعة المحدّبة. الحل: الخطوة 1: المجموعة محدّبة ومتناظرة $\Rightarrow$ \sup جوهريّ سهل حسابه. النتيجة: محدّبة. الربط بالذكاء الاصطناعي: حسابات ثابتة.

مثال (15-3.42): خلاصة المعطيات: p, q متطابقان. المطلوب: W_1. الحل: الخطوة 1: أيّ f 1-Lip يعطي فرقاً =0 $\Rightarrow W_1 = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: تطابق $\Rightarrow$ مسافة صفرية.

أخطاء شائعة

- **الخلط بين $\mathbb{E}_p[f] - \mathbb{E}_q[f]$ والبسيط:** الحد الأقصى بعدّة f 1-Lip هو W1.
- **نسيان ثابت ليبنتس:** بلا قيد الsup يتّجه إلى ما لا نهاية.
- **الظنّ أن W1 = فرق الوسائط دائماً:** صحيح فقط في حالات خاصّة.
- **إهمال الإشارة المثلى:** نختار $\pm f$ حسب الاتجاه.
- **الخلط بين W1 وW2:** W1 كلفة $|x-y|$، W2 كلفة $(x-y)^2$.

صياغة رسمية: بإضافة حدّ إنتروبي $\varepsilon H(\gamma)$ إلى صياغة كانتوروفيتش، نحصل على

$$\mathrm{OT}_\varepsilon(p,q) = \min_{\gamma \in \Pi(p,q)} \big[\langle C, \gamma\rangle - \varepsilon H(\gamma)\big], \qquad \gamma^\star = u\,K\,v^\top \tag{3.42}$$

حيث $K = \exp(-C/\varepsilon)$ وu, v مُعاملات تحجيم (scaling) لضبط الهامشين.

جدول الرموز

الرمز	المعنى
ε	قوّة الانتظام الإنتروبي
K_{ij}	نواة غيبس $e^{-c_{ij}/\varepsilon}$
u, v	مُعاملات التحجيم الصفّيّ/العموديّ

الرسم

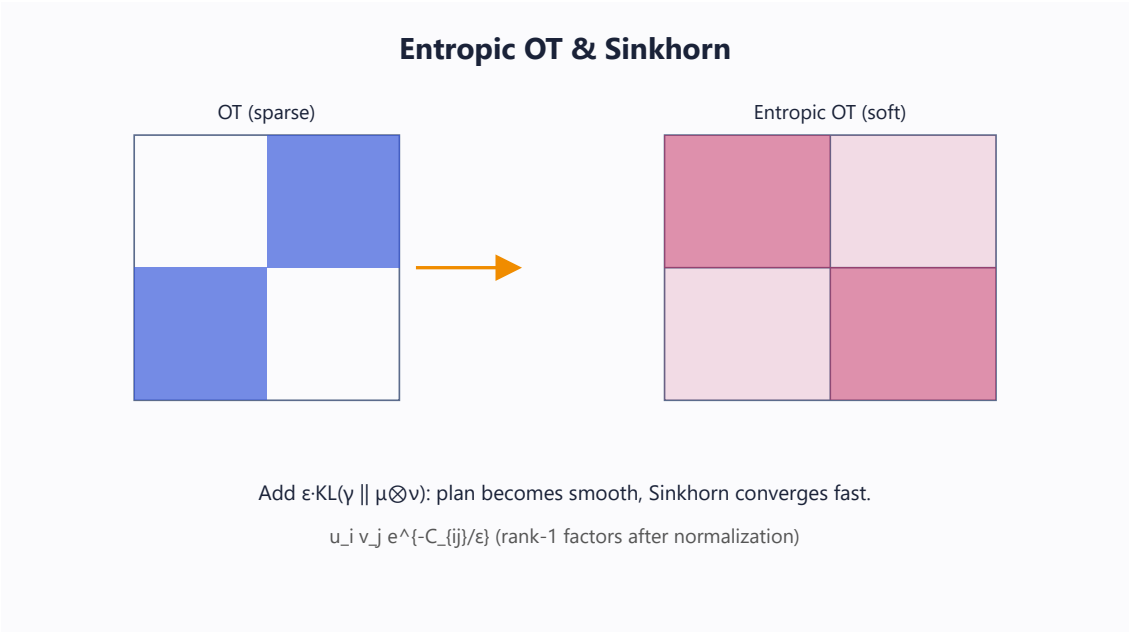
<figure> الشكل 3.42: الانتظام الإنتروبي يفتّح خطة النقل المتناثرة إلى خطة ناعمة قابلة للحساب بـSinkhorn. </figure>

البرهان

الخطوة 1 (الاشتقاق): مشتقّة $-\varepsilon H$ عند γ_{ij} تُضيف $\varepsilon(1 + \log \frac{\gamma_{ij}}{p_i q_j})$؛ القيدان يُنتجان $\gamma^\star = e^{(f_i + g_j - c_{ij})/\varepsilon}$. ■

الخطوة 2 (تفكيك الرتبة-1): بتعريف $u_i = e^{f_i/\varepsilon}$، $v_j = e^{g_j/\varepsilon}$ نحصل $\gamma^\star = uKv^\top$. ■

الخطوة 3 (تكرار Sinkhorn): بالتبادل $u \leftarrow p/(Kv)$، $v \leftarrow q/(K^\top u)$ نُطبّق الهامشين، ويتقارب خطّياً. ■



شكل ٣٠٤٢: *
الانتظام الإنتروبي

خمسة عشر مثالاً محلولاً

مثال (1-4.42): نواة غيبس المعطيات: $C = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$، $\varepsilon = 1$. المطلوب: K. الحل: الخطوة 1: $K_{ij} = e^{-c_{ij}} \Rightarrow$ $K = \begin{bmatrix} e^{-1} & 1 \\ 1 & e^{-1} \end{bmatrix} = \begin{bmatrix} 0.368 & 1 \\ 1 & 0.368 \end{bmatrix}$. النتيجة: $K = \begin{bmatrix} 1 & 0.368 \\ 0.368 & 1 \end{bmatrix}$. الربط بالذكاء الاصطناعي: كلفة أعلى $\Rightarrow$ وزن أدنى.

مثال (2-4.42): أول تكرار Sinkhorn المعطيات: $p = q = (0.5, 0.5)$، K من (1-4.42)، نبدأ $v = (1, 1)$. المطلوب: خطوة تحجيم الصفوف. الحل: الخطوة 1: $Kv = (1.368, 1.368)$؛ $u = p/(Kv) = (0.366, 0.366)$. النتيجة: $u = (0.366, 0.366)$. الربط بالذكاء الاصطناعي: ضبط الصفوف.

مثال (3-4.42): الحدّ $\varepsilon \to \infty$ المعطيات: ε ضخم. المطلوب: $\gamma^\star$. الحل: الخطوة 1: $K \to$ مصفوفة الكل-واحدات؛ $\gamma^\star \to pq^\top$ (الجداء الخارجيّ). النتيجة: $\gamma = p \otimes q$. الربط بالذكاء الاصطناعي: بلا تأثير للكلفة.

مثال (4-4.42): الحدّ $\varepsilon \to 0^+$ المعطيات: $\varepsilon \to 0^+$. المطلوب: $\gamma^\star$. الحل: الخطوة 1: نعود إلى النقل الأمثل غير المنتظَم (منفصل). النتيجة: خطة OT الكلاسيكيّة. الربط بالذكاء الاصطناعي: استرداد الحالة الأصل.

مثال (5-4.42): تأثير ε على النعومة المعطيات: $\varepsilon = 0.1$ مقابل $\varepsilon = 10$. المطلوب: أيهما أكثر نعومة؟ الحل: الخطوة 1: ε أكبر $\Rightarrow$ خطة أكثر توزيعاً (ناعمة). النتيجة: $\varepsilon = 10$ أكثر نعومة. الربط بالذكاء الاصطناعي: مقايضة دقّة/نعومة.

مثال (6-4.42): قيمة إنتروبيّة معدومة المعطيات: كتل موحّدة 2×2، $\gamma_{ij} = 1/4$، $p_i q_j = 1/4$. المطلوب: H. الحل: الخطوة 1: $\gamma_{ij} \log \frac{\gamma_{ij}}{p_i q_j} = \frac{1}{4} \log 1 = 0$ لكلّ مدخل. النتيجة: $H = 0$. الربط بالذكاء الاصطناعي: الجداء الخارجيّ بلا إنتروبيا.

مثال (7-4.42): إنتروبيا موجبة المعطيات: $\gamma_{11} = 0.4$، $p_1 q_1 = 0.25$ (من $\{0.5, 0.5\}$). المطلوب: مساهمة المدخل. الحل: الخطوة 1: $\gamma_{11} \log \frac{\gamma_{11}}{p_1 q_1} = 0.4 \log(1.6) = 0.4 \times 0.470 = 0.188$. النتيجة: 0.188. الربط بالذكاء الاصطناعي: انحراف عن الاستقلال.

مثال (8-4.42): تعقيد Sinkhorn المعطيات: مصفوفة $n \times n$، T تكراراً. المطلوب: التعقيد. الحل: الخطوة 1:

$O(Tn^2)$؛ لأعداد كبيرة يُلجأ لفكّ رتب منخفضة. النتيجة: تربيعيّ في العيّنات. الربط بالذكاء الاصطناعي: قيد حسابيّ.

مثال (4.42-9): كتلة متضخّمة المعطيات: $\gamma_{ij} = 0.4$، $p_i q_j = 0.1$. المطلوب: مساهمة الإنتروبيا. الحل: الخطوة 1: $\gamma_{ij} \log \frac{\gamma_{ij}}{p_i q_j} = 0.4 \log(0.4/0.1) = 0.4 \log 4 = 0.4 \times 1.386 = 0.554$. النتيجة: 0.554. الربط بالذكاء الاصطناعي: انحراف موجب يرفع العقوبة.

مثال (4.42-10): تحجيم الأعمدة المعطيات: بعد ضبط الصفوف نضبط الأعمدة $v = q/(K^\top u)$. المطلوب: الحاجة. الحل: الخطوة 1: ضمان أن أعمدة γ تُحقّق الهامش الثاني q. النتيجة: الهامشان محفوظان. الربط بالذكاء الاصطناعي: تبادل صفوف/أعمدة.

مثال (4.42-11): تقارب بطيء المعطيات: $\varepsilon = 0.05$ صغير جداً. المطلوب: سلوك تقارب Sinkhorn. الحل: الخطوة 1: يتطلّب عدداً كبيراً من التكرارات كي يستقرّ. النتيجة: تقارب بطيء. الربط بالذكاء الاصطناعي: تجنّب ε الصغير.

مثال (4.42-12): خطة قابلة للاشتقاق المعطيات: $\gamma^\star$ ناتج بوابات ناعمة والتدرّجات تسري عبرها. المطلوب: كيف ندرّب مولّداً؟ الحل: الخطوة 1: $\gamma^\star$ دالّة قابلة للاشتقاق نحو المسار الخلفيّ. النتيجة: تدرّب بالرجوع الخلفيّ. الربط بالذكاء الاصطناعي: شبكات OT قابلة للتدرّب.

مثال (4.42-13): مقارنة بالخطة الكلاسيكيّة المعطيات: (2.42-1) غير منتظَم يعطي $\gamma = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix}$. المطلوب: خطة بـ$\varepsilon = 1$. الحل: الخطوة 1: بعد تثبيت Sinkhorn كلّ المداخل > 0 لكن الكلفة القُطريّة مميّزة. النتيجة: ناعمة لكن موضّحة. الربط بالذكاء الاصطناعي: توزيع كتلة موسّع.

مثال (4.42-14): كلفة OT مقابل المنتظَم المعطيات: $\mathrm{OT}_\varepsilon \geq \mathrm{OT}$. المطلوب: لماذا؟ الحل: الخطوة 1: الاسترخاء الإنتروبي يوسّع المجموعة $\Rightarrow$ القيمة لا تقلّ عن المثاليّة. النتيجة: $\mathrm{OT}_\varepsilon \geq \mathrm{OT}$. الربط بالذكاء الاصطناعي: انحياز الاسترخاء.

مثال (4.42-15): خلاصة المعطيات: $\varepsilon = 1$، كلفة $c = 0.5$ لمدخل واحد. المطلوب: الوزن غير المُنتظَم. الحل: الخطوة 1: وزن تقريبيّ $e^{-0.5} = 0.607$ قبل التحجيم. النتيجة: 0.607. الربط بالذكاء الاصطناعي: نواة الأساس.

أخطاء شائعة

- **الخلط بين $\varepsilon \to 0$ و$\varepsilon \to \infty$:** الأول OT كلاسيكيّ، الثاني الجداء الخارجيّ.
- **نسيان الحفاظ على الهامشين:** لا بدّ من تبادل التحجيم حتى التثبيت.
- **الخلط بين $+\varepsilon H$ و$-\varepsilon H$:** في (3.42) نضيف $-H$ لا $+H$.
- **اختيار ε صغير جداً:** يُبطئ تقارب Sinkhorn كثيراً.
- **ظنّ أن $\gamma^\star$ منفصل:** مع $\varepsilon > 0$ يكون ناعماً موجباً كلّه.

صياغة رسمية: بثنائية KR، تُصاغ مسافة واسرشتاين-1 بين بيانات وناتج كـ

$$W_1(p_{data}, p_g) = \sup_{\|f\|_L \leq 1} \mathbb{E}_{x \sim p_{data}}[f(x)] - \mathbb{E}_{x \sim p_g}[f(x)] \tag{4.42}$$

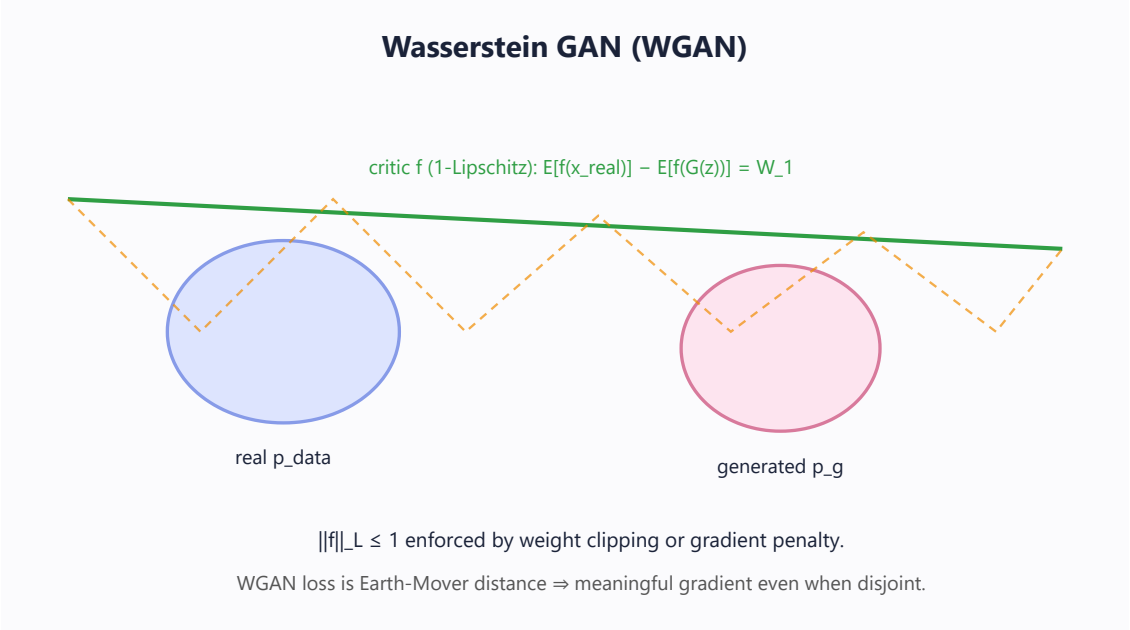
ونُدرّب "الناقد" f لتعظيم الفرق بشرط ثابت ليبنتس ≤ 1، والمولّد لتصغيره.

جدول الرموز

الرمز	المعنى
f	الناقد (critic)
$\|f\|_L \le 1$	قيد ثابت ليبنتس
GP	عقوبة التدرّج $(\|\nabla f\| - 1)^2$

الرسم

<figure> الشكل<figcaption> 4.42: الناقد يقدّر الفرق بين التوزيعين تحتّ قيد ثابت ليبنتس 1؛ المولّد



شكل ٤٢.٤٢: *
ناقد WGAN

يقلّله.<figcaption/> </figure>

البرهان

الخطوة 1 (تأسيس :(KR) من (2.42) نُدرّب ناقداً بثابت ليبنتس $1 \le$ لتقدير W_1. ■

الخطوة 2 (تدرّج مفيد): خلافاً لتباعد JS، W_1 يعطي تدرّجاً غير معدوم حتى للتوزيعات المنفصلة. ■

الخطوة 3 (فرض القيد): عملياً نفرضه بقصّ الأوزان (weight clipping) أو بعقوبة التدرّج GP: $\lambda(\|\nabla f\|_2 - 1)^2$. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.42): الفرق عبر الهويّة المعطيات: $f(x) = x$ (ثابت ليبنتس 1)، p وسطه 0.5، q وسطه 2. المطلوب: القيمة. الحل: الخطوة 1: $\mathbb{E}_p[f] - \mathbb{E}_q[f] = 0.5 - 2 = -1.5$؛ بالقيمة المطلقة $|-1.5| = 1.5$. النتيجة: 1.5 (حدّ أدنى لـW_1). الربط بالذكاء الاصطناعي: حدّ فرق الوسائط.

مثال (2-5.42): قصّ الأوزان المعطيات: أوزان الناقد محدودة بـ$[-c, c]$، $c = 0.01$. المطلوب: الأثر. الحل: الخطوة 1: يفرض تقريبياً $\|f\|_L \le 1$ (بمجموع حدود) لكن قاسٍ. النتيجة: قيد تقريبيّ. الربط بالذكاء الاصطناعي: تقنية مبسّطة.

مثال (42.5-3): عقوبة التدرّج المعطيات: $\lambda = 10$، $\|\nabla f\| = 1.3$. المطلوب: قيمة عقوبة GP. الحل: الخطوة 1: $(1.3-1)^2 = 0.09$؛ $\times 10 = 0.9$. النتيجة: 0.9. الربط بالذكاء الاصطناعي: فرض ليبنتس ناعم.

مثال (42.5-4): مقارنة WGAN/WGAN-GP المعطيات: قصّ الأوزان مقابل GP. المطلوب: أيهما أفضل استقراراً؟ الحل: الخطوة 1: GP أكثر استقراراً وأقلّ انحيازاً من القصّ. النتيجة: GP أفضل. الربط بالذكاء الاصطناعي: المعيار العمليّ.

مثال (42.5-5): فائدة W1 على JS المعطيات: p, q منفصلان (لا تداخل). المطلوب: سلوك التدرّج. الحل: الخطوة 1: JS يتشبّع (مشتقّته ≈ 0)؛ W1 يبقى ذا تدرّج مفيد. النتيجة: W1 يتدرّب بأمان. الربط بالذكاء الاصطناعي: حلّ التدرّج المعدوم.

مثال (42.5-6): W1 يعكس البُعد المعطيات: q أبعد من p بمعزل أكبر. المطلوب: سلوك W_1 مقارنة بـTV. الحل: الخطوة 1: W1 يزيد مع البُعد؛ TV يظلّ ثابتاً بلا تداخل. النتيجة: W1 هندسيّ. الربط بالذكاء الاصطناعي: تدرّج موجّه جغرافياً.

مثال (42.5-7): انهيار النمط المعطيات: مولّد يولّد نقطة واحدة (انهيار). المطلوب: ماذا يقيس W1؟ الحل: الخطوة 1: W_1 يظلّ كبيراً لأنّ النقل يكلّف بُعداً $\Rightarrow$ عقوبة مستمرّة. النتيجة: يكشف الانهيار. الربط بالذكاء الاصطناعي: ثبات التوليد.

مثال (42.5-8): سعة الناقد المعطيات: شبكة ضحلة مقابل شبكة عميقة. المطلوب: الأثر على تقدير W1. الحل: الخطوة 1: ناقد غير كافٍ $\Rightarrow$ تقدير W1 أقلّ (تحيّز أدنى). النتيجة: سعة كافية مطلوبة. الربط بالذكاء الاصطناعي: موازنة القدرة.

مثال (42.5-9): جدول تدريب المعطيات: لكلّ خطوة مولّد 5 خطوات ناقد. المطلوب: لماذا أكثر للناقد؟ الحل: الخطوة 1: ليقارب التوزيع الأمثل 1-Lip جيّداً قبل كلّ خطوة مولّد. النتيجة: تثبيت تقدير W1. الربط بالذكاء الاصطناعي: جدولة WGAN.

مثال (42.5-10): الفرق المتوقّع المعطيات: $\mathbb{E}[f(x_r)] = 0.8$، $\mathbb{E}[f(G(z))] = 0.2$. المطلوب: هدف الناقد (تعظيم) والقيمة. الحل: الخطوة 1: $0.6 = 0.2 - 0.8$ (نرفعه للحراك)؛ المولّد يخفضه. النتيجة: 0.6. الربط بالذكاء الاصطناعي: ديناميكا اللعبة.

مثال (42.5-11): معامل GP الأمثل المعطيات: $\lambda = 10$ قياسيّ (WGAN-GP). المطلوب: عند الحاجة إليه. الحل: الخطوة 1: يمنع فرط تدرّج/انفجاره؛ القيمة قياسيّة متّسقة. النتيجة: $\lambda \approx 10$. الربط بالذكاء الاصطناعي: اختيار عمليّ.

مثال (42.5-12): التقارب عند النهاية المعطيات: $p_g \to p_{data}$. المطلوب: قيمة الهدف الذهبيّة. الحل: الخطوة 1: $W_1 \to 0 \Rightarrow$ كلّ f تعطي فرقاً ≈ 0. النتيجة: 0. الربط بالذكاء الاصطناعي: مؤشّر إتمام.

مثال (42.5-13): ثبات ليبنتس بشبكة المعطيات: ناقد خطوطي Wx، $\|W\|_2 \leq 1$. المطلوب: $\|f\|_L$. الحل: الخطوة 1: الثابت أكبر قيمة مفردة لـ$W \Rightarrow$ نفرض $\|W\|_2 \leq 1$. النتيجة: قيد معتاد. الربط بالذكاء الاصطناعي: تنظيم معياريّ.

مثال (42.5-14): مقارنة GAN/WGAN المعطيات: GAN بـJS، WGAN بـW1. المطلوب: بضاعة التدريب. الحل: الخطوة 1: WGAN أقدر على الاستمرار ويُقلّل انهيار النمط. النتيجة: WGAN أكثر استقراراً. الربط بالذكاء الاصطناعي: سبب الشعبيّة.

مثال (42.5-15): خلاصة المعطيات: ناقد مثاليّ بثابت ليبنتس 1. المطلوب: الهدف الفعليّ. الحل: الخطوة 1: يساوي $W_1(p_d, p_g) = \mathbb{E}_{p_d}[f^\star] - \mathbb{E}_{p_g}[f^\star]$. النتيجة: W_1. الربط بالذكاء الاصطناعي: ربط الثنويّة بحالة الناقد العمليّة.

أخطاء شائعة

- **نسيان قيد ليبنتس:** بلا ثابت $\text{sup} \leq 1$ لا نهائيّ وغيّر واجهة الهدف.
- **الاعتماد على قصّ الأوزان فقط:** قاسٍ وغير مستقرّ؛ يُفضّل GP.
- **الظنّ أن f يقدّر كثافة:** WGAN يقابل دوالاً 1-Lip لا كثافة.
- **الخلط بين GAN/WGAN:** JS مقابل W1 (تدرّج معدوم مقابل مفيد).
- **إهمال جدولة الناقد:** يتطلّب خطوات ناقد أكثر ليتقارب W1.

صياغة رسمية: بالكلفة التربيعيّة، مسافة واسرشتاين-2 هي

$$W_2^2(p,q) = \min_{T:\ T_\# p = q} \int \|x - T(x)\|^2 \, dp(x) \tag{5.42}$$

وعند كلفة تربيعيّة وp مُطلق الاستمراريّة، توجد خريطة مثلى وحيدة (Brenier) هي تدرّج دالّة محدّبة: $T^\star = \nabla \psi$.

جدول الرموز

الرمز	المعنى
$T_\# p = q$	T تدفع p إلى q
ψ	دالّة محدّبة (Brenier)
W_2	واسرشتاين-2

الرسم

<figure> الشكل<figcaption> 5.42: الخريطة المثلى تقلب p إلى q بأقلّ اتساع تربيعيّ؛ للغاوسيّين هي خريطة أفينيّة وحديدة.</figcaption> </figure>

البرهان

الخطوة 1 (صياغة مونج): نبحث عن خريطة T تدفع p إلى q بأقلّ كلفة. ■

الخطوة 2 (نظريّة Brenier): وجود ψ محدّبة، $T^\star = \nabla \psi$ الخريطة الوحيدة المثلى. ■

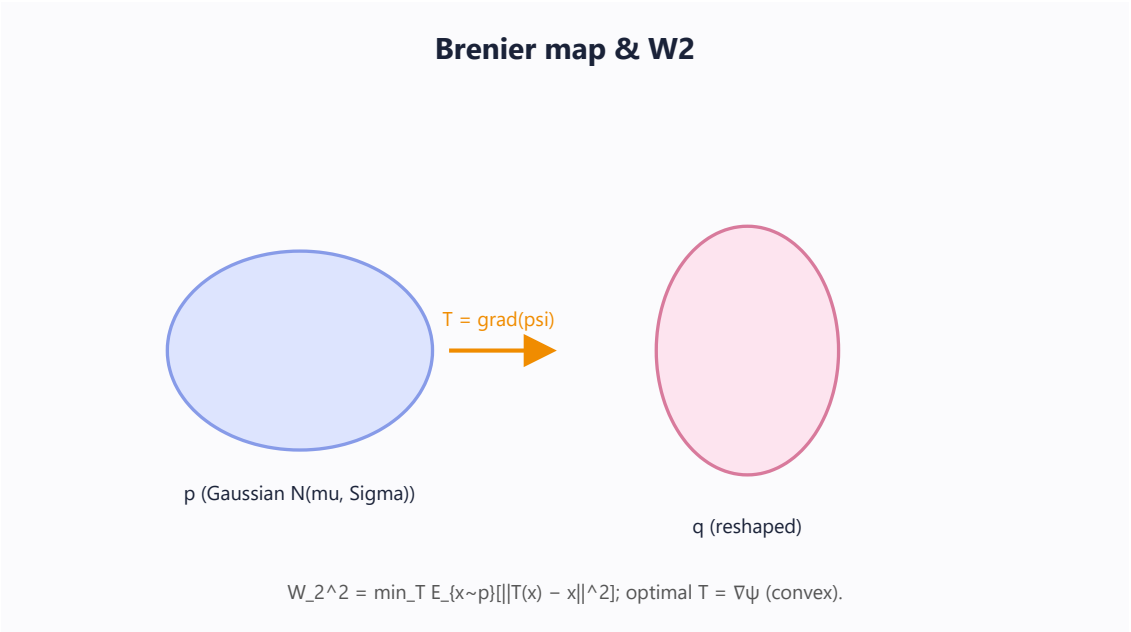
الخطوة 3 (حالة غاوسيّة): لغاوسيّين $T(x) = A(x - \mu_p) + \mu_q$، $A = \Sigma_p^{-1/2} (\Sigma_p^{1/2} \Sigma_q \Sigma_p^{1/2})^{1/2} \Sigma_p^{-1/2}$، و$W_2^2 = \|\mu_p - \mu_q\|^2 + \operatorname{Tr}(\Sigma_p + \Sigma_q - 2(\cdots))$. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.42): كتلتان نقطيّتان المعطيات: p عند 0، q عند 2 (بلا انتشار). المطلوب: W_2. الحل: الخطوة 1: كلّ الكتلة تُنقل من 0 إلى 2؛ $W_2^2 = 2^2 = 4$. النتيجة: $W_2 = 2$. الربط بالذكاء الاصطناعي: مسافة النقاط.

مثال (2-6.42): غاوسيّان بنفس التباين المعطيات: $\mu_p = 0, \mu_q = 3$، $\Sigma_p = \Sigma_q = 1$. المطلوب: W_2. الحل: الخطوة 1: فرق الوسائط فقط $\Rightarrow W_2 = |3 - 0| = 3$. النتيجة: 3. الربط بالذكاء الاصطناعي: W2 = إزاحة الوسائط.

مثال (3-6.42): تباين مختلف (1D) المعطيات: $\mu_p = \mu_q = 0$، $\Sigma_p = 1, \Sigma_q = 4$. المطلوب: W_2. الحل: الخطوة 1: $W_2^2 = 1 + 4 - 2\sqrt{1 \cdot 4} = 5 - 4 = 1$. النتيجة: $W_2 = 1$. الربط بالذكاء الاصطناعي: وسطي التباين.



شكل ٥.٤٢: *
خريطة Brenier

مثال (4-6.42): بعد ثنائيّ المعطيات: $\Sigma_p = \mathrm{diag}(1,1)$، $\Sigma_q = \mathrm{diag}(4,9)$، وسطان متطابقان. المطلوب: W_2. الحل: الخطوة 1: $W_2^2 = (1+4-2\cdot 2)+(1+9-2\cdot 3) = 1+4 = 5$. الخطوة 2: $W_2 = \sqrt{5} \approx 2.236$. النتيجة: 2.236. الربط بالذكاء الاصطناعي: يجمع مساهمات الأبعاد.

مثال (5-6.42): الخريطة الأفينيّة المعطيات: للحالة (4-6.42). المطلوب: مُعامِل الخريطة لكلّ بُعد. الحل: الخطوة 1: $A = \mathrm{diag}(\sqrt{4/1}, \sqrt{9/1}) = \mathrm{diag}(2,3)$. النتيجة: $\mathrm{diag}(2,3)$. الربط بالذكاء الاصطناعي: توسيعٌ قُطريّ.

مثال (6-6.42): وحدة الخريطة المعطيات: هل $T^\star$ وحيدة لـBrenier؟ المطلوب: علّق. الحل: الخطوة 1: نعم، تدرّج دالّة محدّبة $\Rightarrow$ وحيدة (حتى ثابت). النتيجة: وحيدة. الربط بالذكاء الاصطناعي: تحديد مثاليّ.

مثال (7-6.42): حدود فرق الوسائط المعطيات: أيّ p, q. المطلوب: علاقة W_2 بفرق الوسائط. الحل: الخطوة 1: $W_2(p,q) \geq \|\mu_p - \mu_q\|$ (مع تطابق توزيع غير الوسائط). النتيجة: W2 يهبط حدّ أدنى. الربط بالذكاء الاصطناعي: ثابت هندسيّ.

مثال (8-6.42): المتوسط الهندسيّ المعطيات: في W_2^2، الحدّ $\mathrm{Tr}(\Sigma_p+\Sigma_q-2(\Sigma_p\Sigma_q)^{1/2})$ قيس تباين. المطلوب: أعطه مثالاً عدديّاً. الحل: الخطوة 1: من (3-6.42): $1+4-2\cdot 2 = 1$ وهو $(\sqrt{\Sigma_q}-\sqrt{\Sigma_p})^2$. النتيجة: فرق الجذور مربّعاً. الربط بالذكاء الاصطناعي: التباين يسقط على الجذر.

مثال (9-6.42): W2 كمتر المعطيات: خصائص المسافة. المطلوب: تحقّق $W_2(p,q) = 0 \iff p = q$. الحل: الخطوة 1: إنّ $W_2 = 0 \Rightarrow$ خريطة الهويّة تكفي $\Rightarrow p = q$. النتيجة: ينفي التطابق. الربط بالذكاء الاصطناعي: مسافة قياسيّة.

مثال (10-6.42): استقلال الأبعاد المعطيات: $p = p_1 \otimes p_2$، $q = q_1 \otimes q_2$؛ $W_2^2(p,q) = W_2^2(p_1,q_1) + W_2^2(p_2,q_2)$. المطلوب: لحالة p_1, q_1 فرق وسائط 1؛ p_2, q_2 فرق 2. الحل: الخطوة 1: $W_2^2 = 1^2+2^2 = 1+4 = 5 \Rightarrow W_2 = \sqrt{5} = 2.236$. النتيجة: $\sqrt{5}$. الربط بالذكاء الاصطناعي: تتجمّع المسافات جذريّاً عبر الأبعاد.

مثال (11-6.42): مقارنة W1 وW2 المعطيات: $p = q$ مُزاحاً بواسطة d على خطّ. المطلوب: W_1 مقابل W_2. الحل: الخطوة 1: $W_1 = d$ (كلفة مطلقة)؛ $W_2 = d$ (كلفة تربيعيّة لاتساع d^2 بجذرها d) هنا للكتلة النقطيّة. النتيجة:

متطابقتان نقطيّاً. الربط بالذكاء الاصطناعي: يتفارقان عموماً.

مثال (6.42-12): دالّة محدّبة ψ المعطيات: $T^\star = \nabla\psi$، لحالة (6.42-5)، $T = \mathrm{diag}(2,3)x$. المطلوب: ψ (حتى ثابت). الحل: الخطوة 1: $\psi(x) = x_1^2 + \tfrac{3}{2}x_2^2$ (محدّبة). النتيجة: $\psi(x) = x_1^2 + \tfrac{3}{2}x_2^2$. الربط بالذكاء الاصطناعي: دالّية محدّبة أساسية.

مثال (6.42-13): انكماش التوزيع المعطيات: $\Sigma_p \succ \Sigma_q$ (بانتظام). المطلوب: A كمقلوب. الحل: الخطوة 1: A تتحرّك بأقلّ من الهويّة (تصغير) نحو مساحة أصغر. النتيجة: تصغير. الربط بالذكاء الاصطناعي: انكماش العيّنات.

مثال (6.42-14): قياس عدديّ المعطيات: $\mu_p = (0,1), \mu_q = (3,5)$، Σ متطابقة. المطلوب: W_2. الحل: الخطوة 1: $\|\Delta\mu\| = \sqrt{(3-0)^2 + (5-1)^2} = \sqrt{9+16} = 5$. النتيجة: 5. الربط بالذكاء الاصطناعي: مسافة الإزاحة.

مثال (6.42-15): خلاصة المعطيات: $p = q$. المطلوب: W_2. الحل: الخطوة 1: الخريطة المثلى الهويّة $\Rightarrow W_2 = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: التطابق صفريّ.

أخطاء شائعة

- **الخلط بين W1 وW2:** كلفة مطلقة مقابل تربيعيّة.
- **نسيان جذر التباين:** الحدّ $\mathrm{Tr}(\cdot)$ يُحسب قبل الجذر.
- **ظنّ أن الخريطة خطّية دائماً:** خطّية فقط للغاوسيّين.
- **إهمال شرط "مطلق الاستمراريّة":** Brenier يتطلّب p كثيفةً عددياً.
- **الخلط بين** $\Sigma_p^{1/2}\Sigma_q\Sigma_p^{1/2}$ **و**$\Sigma_p\Sigma_q$**:** الترتيب غير تبادليّ.

صياغة رسمية: لتقليل دالّية $\mathcal{F}(\rho)$ في فضاء واسرشتيين، مخطّط JKO الزمنيّ-الضمنيّ هو

$$\rho_{n+1} = \arg\min_{\rho} \frac{1}{2\tau} W_2^2(\rho, \rho_n) + \mathcal{F}(\rho) \tag{6.42}$$

وحين $\tau \to 0$ يتقارب إلى معادلة الانسياب مع سرعة $v = -\nabla_W \mathcal{F}$ (تدرّج W_2).

جدول الرموز

الرمز	المعنى
τ	خطوة الزمن
$\mathcal{F}$	دالّية الطاقة
$\nabla_W \mathcal{F}$	تدرّج واسرشتيين

الرسم

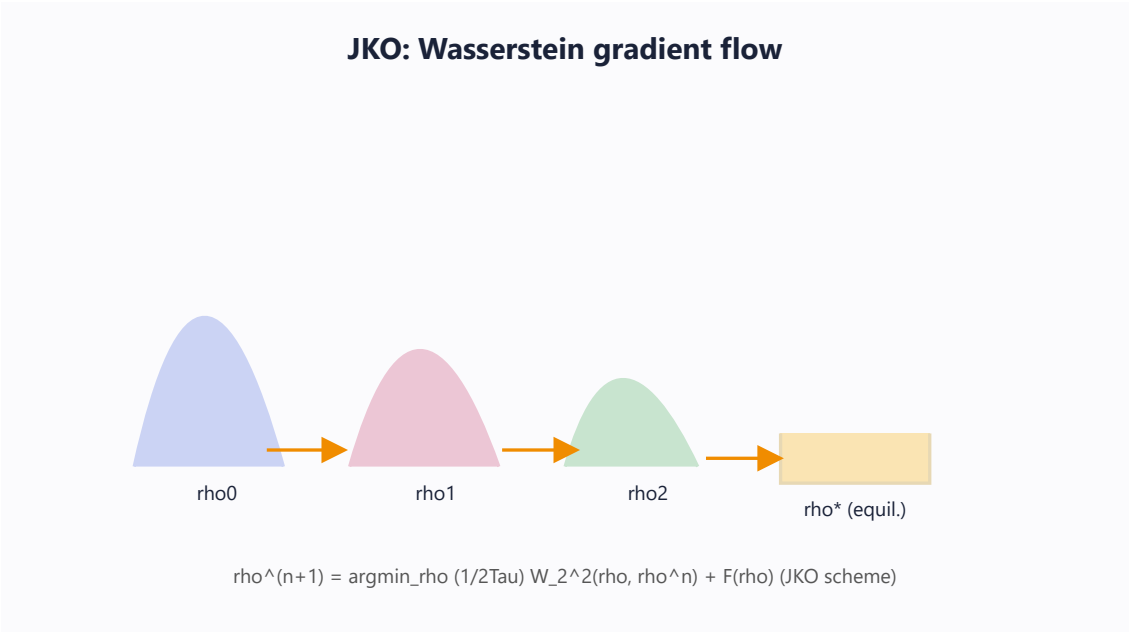
<figure>الشكل 6.42: التكاملات المتوالية لصيغ JKO تُحرّك الكثافة $\rho^0 \to \rho^1 \to \rho^2$ نحو توازن $\rho^\star$.</figure>

البرهان

الخطوة 1 (تقسيم ضمنيّ): كلّ خطوة تُقارب ρ_{n+1} بتدبير حدّي: القرب من ρ_n بمسافة W_2، وهبوط في $\mathcal{F}$. ■

الخطوة 2 (الشرط الأمثليّ): الخريطة المثلى بين ρ_n وρ_{n+1} تُحدّد السرعة v؛ $v = -\nabla\mathcal{F}(\rho_{n+1})$. ■

الخطوة 3 (الحدّ الأملس): $\tau \to 0$ يعطي معادلة الانسياب $\partial_t\rho + \nabla\cdot(\rho v) = 0$. ■



شكل ٦٠٤٢: *
تدفّق JKO

خمسة عشر مثالاً محلولاً

مثال (1-7.42): طاقة معدومة المعطيات: $\mathcal{F} = 0$. المطلوب: تطوّر ρ. الحل: الخطوة 1: الـarg min يصير $\rho_{n+1} = \rho_n$ (لا حركة). النتيجة: ثابت. الربط بالذكاء الاصطناعي: بلا قوة دافعة.

مثال (2-7.42): طاقة إنتروبيّة المعطيات: $\mathcal{F}(\rho) = \int \rho \log \rho$. المطلوب: المعادلة المحصّلة. الحل: الخطوة 1: الحدّ يعطي معادلة الحرارة (انتشار) $\partial_t \rho = \Delta \rho$. النتيجة: تمليس تدريجيّ. الربط بالذكاء الاصطناعي: معادلة الحرارة تُنتشر البيانات.

مثال (3-7.42): جهد تربيعيّ المعطيات: $\mathcal{F} = \int \frac{1}{2} x^2 \rho \, dx$. المطلوب: سلوك الوسيط. الحل: الخطوة 1: الوسيط يهبط نحو 0؛ $\mu_{n+1} = e^{-\tau} \mu_n$ تقريباً. النتيجة: انحدار أسيّ. الربط بالذكاء الاصطناعي: جذب نحو القاع.

مثال (4-7.42): خطوة JKO عدديّاً المعطيات: $\tau = 0.1$، ρ_0 غاوسيّ وسطه 1، جهد $x^2/2$. المطلوب: μ_1. الحل: الخطوة 1: $\mu_1 = e^{-0.1} \cdot 1 \approx 0.905$. النتيجة: 0.905. الربط بالذكاء الاصطناعي: تقارب نحو 0.

مثال (5-7.42): استرخاء التباين المعطيات: $\rho_0 \sim \mathcal{N}(0, 4)$، توازن $\mathcal{N}(0, 1)$، $\tau = 0.1$. المطلوب: Σ_1. الحل: الخطوة 1: $e^{-2\tau} = e^{-0.2} = 0.819$؛ $\Sigma_1 = 4 \times 0.819 + (1 - 0.819) = 3.274 + 0.181 = 3.456$. النتيجة: 3.456. الربط بالذكاء الاصطناعي: تقارب نحو 1.

مثال (6-7.42): تدرّج واسرشتين للإنتروبيا المعطيات: $\nabla_W (\int \rho \log \rho)$ عند ρ_n. المطلوب: الصيغة. الحل: الخطوة 1: يساوي $\nabla \log \rho_n$ (تدرّج كثافة). النتيجة: $\nabla \log \rho_n$. الربط بالذكاء الاصطناعي: ربط بالسكور.

مثال (7-7.42): طاقة حرة المعطيات: $\mathcal{F} = \int [V \rho + \rho \log \rho]$. المطلوب: النوع. الحل: الخطوة 1: معادلة فوكر-بلانك؛ توازنها غاوسيّ مُرجّح بـ e^{-V}. النتيجة: فوكر-بلانك. الربط بالذكاء الاصطناعي: توليد من العيّنات.

مثال (8-7.42): التوازن النهائيّ المعطيات: $\mathcal{F}$ محدودة سفليّاً وτ كافٍ. المطلوب: هدف المسلسل. الحل: الخطوة 1: يتقارب إلى حدّ أصغر $\mathcal{F}$ (توازن). النتيجة: توازن $\rho^\star$. الربط بالذكاء الاصطناعي: نقطة استقرار.

مثال (9-7.42): مستوى جهد المعطيات: $V(x) = |x|$. المطلوب: شكل التوازن (تقريبيّ). الحل: الخطوة 1: كتلة تتمركز عند القاع $x = 0$ (لابلاسيّ مثلاً). النتيجة: مركّزة عند 0. الربط بالذكاء الاصطناعي: تكوين متوسط.

مثال (10-7.42): JKO منفصل المعطيات: تمثيل منفصل لنُهج الذرّيّة. المطلوب: بيان المصطلح. الحل: الخطوة 1: نُقرّب W_2^2 عبر جذب زوجيّ منفصل .(matching) النتيجة: خوارزميّة JKO منفصلة. الربط بالذكاء الاصطناعي: قابل للحساب رقميّاً.

مثال (11-7.42): انحسار الطاقة المعطيات: $\mathcal{F}(\rho_{n+1}) \le \mathcal{F}(\rho_n)$. المطلوب: تحقّق. الحل: الخطوة 1: كلّ خطوة JKO لا ترفع $\mathcal{F}$ (تهبيط مضمون). النتيجة: هبوط رتيب. الربط بالذكاء الاصطناعي: ثبات العدديّ.

مثال (12-7.42): مقارنة بالطريقة الصريحة المعطيات: خطوة أويلر الصريحة على الفضاء. المطلوب: فائدة JKO. الحل: الخطوة 1: JKO ضمنيّة $\Rightarrow$ أكثر استقراراً (بلا قيد خطوة صارم). النتيجة: استقرار أعلى. الربط بالذكاء الاصطناعي: تفوّق ضمنيّ.

مثال (13-7.42): خرائط حركة المعطيات: $T_n = (id + \tau \nabla \mathcal{F}(\rho_n))$ (نحو الأمام). المطلوب: $\rho_{n+1} = T_{n\#}\rho_n$. الحل: الخطوة 1: نُطبّق الخريطة على العيّنات لتحديث الكثافة. النتيجة: تحديث بالخريطة. الربط بالذكاء الاصطناعي: كلفة $\mathrm{O(n)}$.

مثال (14-7.42): ربط الانتشار بـSinkhorn المعطيات: خطوة JKO تُحسب بنقل أملس (Sinkhorn) للحالات المعقّدة. المطلوب: علّق. الحل: الخطوة 1: الانتظام الإنتروبي يجعل W_2^2 تقريبياً قابلاً للحساب. النتيجة: جسر نظريّ-عمليّ. الربط بالذكاء الاصطناعي: ربط (4.42) بـ(7.42).

مثال (15-7.42): خلاصة المعطيات: $\tau \to 0$، $\mathcal{F}$ مركّزة. المطلوب: حدّ المسلسل الزمنيّ. الحل: الخطوة 1: تدفّق مستمرّ يهبط نحو قاع $\mathcal{F}$ على أقصر مسار W_2. النتيجة: تدفّق واسرشتيين. الربط بالذكاء الاصطناعي: التحسين الهندسيّ.

أخطاء شائعة

- **الخلط بين JKO والصريح:** JKO ضمنيّ زمنيّاً (انحسار أقوى).
- **نسيان حدّ الانتظام:** يحتاج $\mathcal{F}$ محدوداً سفليّاً لضمان التقارب.
- **الظنّ أن $\rho_{n+1} = \rho_n + \tau v$:** بل يُحسب بإعادة وزن .(pusfhorward)
- **الخلط بين ∇_W والتدرّج الاعتياديّ:** تدرّج واسرشتيين غير الاعتياديّ.
- **إهمال ثبات الطاقة:** JKO يضمن الهبوط رغم الأخطاء العدديّة.

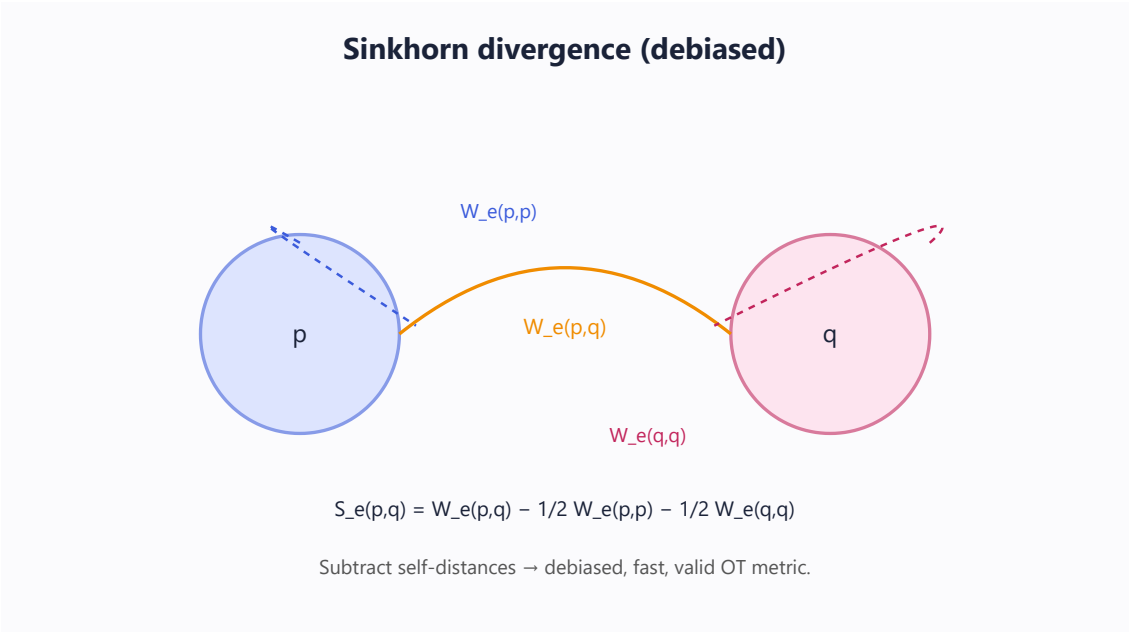
صياغة رسمية: $W_\varepsilon(p,q)$ مُنحاز (لا يُصفّر حتّى عند $p = q$). تباعد Sinkhorn المصحّح هو

$$S_\varepsilon(p,q) = W_\varepsilon(p,q) - \tfrac{1}{2} W_\varepsilon(p,p) - \tfrac{1}{2} W_\varepsilon(q,q) \tag{7.42}$$

وهو متماثل، موجب تماماً، ويتقارب إلى $W_2(p,q)$ بمعدّل $O(\varepsilon)$.

جدول الرموز

الرمز	المعنى
W_ε	كلفة النقل المنتظَمة
S_ε	تباعد Sinkhorn المصحّح
نزع التحيز	طرح حدود الذات



شكل ٧.٤٢: *
تباعد Sinkhorn المصحّح

الرسم

<figure> الشكل<figcaption> 7.42: نطرح حدود النقل الذاتيّ $W_\varepsilon(p,p)$ و$W_\varepsilon(q,q)$ لنزع تحيز المسافة.</figcaption> </figure>

البرهان

الخطوة 1 (مصدر التحيز): عاقبة $-\varepsilon H$ تُنتج كلفة موجبة حتّى لنقل توزيع إلى نفسه. ■

الخطوة 2 (نزع التحيز): طرح $\frac{1}{2}W_\varepsilon(p,p) + \frac{1}{2}W_\varepsilon(q,q)$ يعطي مساوية صفراً عند $p = q$. ■

الخطوة 3 (الحدّ): مع $\varepsilon \to 0$ يحفظ $\frac{1}{2}(p,p), \frac{1}{2}(q,q)$ أوّلاً، فيبقى $S_\varepsilon \to W_2$. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.42): نزع التحيز لـ $p = q$ المعطيات: $p = q$، $W_\varepsilon(p,p) = 0.1$. المطلوب: $S_\varepsilon(p,p)$. الحل: الخطوة 1: $0.1 - \frac{1}{2}(0.1) - \frac{1}{2}(0.1) = 0.1 - 0.1 = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: تطابق $\Rightarrow$ مسافة صفرية.

مثال (2-8.42): حالة عامّة المعطيات: $W_\varepsilon(p,q) = 0.3$، $W_\varepsilon(p,p) = 0.1$، $W_\varepsilon(q,q) = 0.1$. المطلوب: S_ε. الحل: الخطوة 1: $0.3 - 0.05 - 0.05 = 0.2$. النتيجة: 0.2. الربط بالذكاء الاصطناعي: قيمة مُنزَّعة التحيز.

مثال (3-8.42): تحيّز بلا تصحيح المعطيات: $p = q$، $W_\varepsilon = 0.12$. المطلوب: القيمة الخامّة. الحل: الخطوة 1: $W_\varepsilon(p,q) = 0.12 \neq 0$ (مُتحيّز أعلى). النتيجة: 0.12 (خطأ صغير). الربط بالذكاء الاصطناعي: يحتاج التصحيح.

مثال (4-8.42): تماثل المسافة المعطيات: $S_\varepsilon(q,p)$ مقابل $S_\varepsilon(p,q)$. المطلوب: المقارنة. الحل: الخطوة 1: S متماثل $\Rightarrow \frac{1}{2}W_\varepsilon(p,p) + \frac{1}{2}W_\varepsilon(q,q)$ متماثل. النتيجة: متماثل. الربط بالذكاء الاصطناعي: مسافة قياسيّة.

مثال (5-8.42): الإيجابيّة التامّة المعطيات: $p \neq q$. المطلوب: هل $S_\varepsilon > 0$؟ الحل: الخطوة 1: نعم؛ يُظهر سالبيّة فقط عند التطابق تماماً. النتيجة: $0 >$. الربط بالذكاء الاصطناعي: موجب تماماً.

مثال (6-8.42): كفاءة العيّنة المعطيات: W_ε الخامّ يتحيّز لعيّنات صغيرة؛ S_ε يقلّ التحيز. المطلوب: الفائدة. الحل:

الخطوة 1: تقدير مُنزَّع التحيز أدقّ بعدد أقلّ من العيّنات. النتيجة: كفاءة أعلى. الربط بالذكاء الاصطناعي: مقايضة عمليّة.

مثال (8.42-7): معدّل التقارب المعطيات: $|S_\varepsilon - W_2| \le \varepsilon \cdot \lambda_{\max}$، $\lambda_{\max} = 1$، $\varepsilon = 0.01$. المطلوب: حدّ الخطأ. الحل: الخطوة 1: $0.01 = 0.01 \times 1 \le$. النتيجة: 0.01. الربط بالذكاء الاصطناعي: خطأ منتظَم محدود.

مثال (8.42-8): تدرّج نحو W_2 المعطيات: $\varepsilon = 0.1$ مقابل $\varepsilon = 0.001$. المطلوب: أيّ أقرب لـW_2؟ الحل: الخطوة 1: $\varepsilon = 0.001$ أقرب (حدّ التقارب $O(\varepsilon)$). النتيجة: الأصغر. الربط بالذكاء الاصطناعي: اختيار ε.

مثال (8.42-9): تكلفة حسابية المعطيات: ثلاث مرات حساب W_ε (لـp, q, p, p, q, q). المطلوب: النسبة. الحل: الخطوة 1: ثلاثة أضعاف، لكن $W_\varepsilon(p,p)$ يُحسب مرّة ويُعاد استخدامه. النتيجة: نحو $3\times$ رخيصة نسبيّاً. الربط بالذكاء الاصطناعي: مقارنة مقبولة.

مثال (8.42-10): استخدام في التوليد المعطيات: خسارة مولّد $S_\varepsilon(p_{data}, p_g)$. المطلوب: لماذا لا W_ε الخامّة؟ الحل: الخطوة 1: التدرّج نحو الخامّة ينجذب لانحياز الذات لا نحو البيانات. النتيجة: تصحيح ضروريّ. الربط بالذكاء الاصطناعي: أساس نماذج Sinkhorn.

مثال (8.42-11): مثال مُنزَّح عمليّ المعطيات: $W_\varepsilon(p,q) = 0.05$، الذاتيّان 0.02 لكلّ. المطلوب: S_ε. الحل: الخطوة 1: $0.05 - 0.01 - 0.01 = 0.03$. النتيجة: 0.03. الربط بالذكاء الاصطناعي: نصف التحيّز يُزال.

مثال (8.42-12): تدرّج نحو التوزيعات المعطيات: $\nabla_p S_\varepsilon$ يصف كيف نُحرّك العيّنات. المطلوب: علّه مفيد. الحل: الخطوة 1: يعطي اتجاهاً لتحسين العيّنات نحو p_{data} (Wasserstein gradient). النتيجة: تدرّج إنتاجيّ. الربط بالذكاء الاصطناعي: تدريب المولّد بتدرّج واسرشتيين.

مثال (8.42-13): حدّ ε كبير المعطيات: $\varepsilon \to \infty$. المطلوب: سلوك S_ε. الحل: الخطوة 1: كلّ حدود $W_\varepsilon \to 0 \Rightarrow S_\varepsilon \to 0$ (يهبط). النتيجة: يتلاشى. الربط بالذكاء الاصطناعي: ε متوسط أفضل.

مثال (8.42-14): سقف المقارنة مع W1 المعطيات: $W_2 \approx S_\varepsilon(\varepsilon\text{small})$، وأُكملت بـW1 في WGAN. المطلوب: الفرق. الحل: الخطوة 1: W_2 يفضّل التشابه الهندسيّ الكلّيّ؛ W_1 يحترم الخطوط المستوية. النتيجة: W_1 vs W_2. الربط بالذكاء الاصطناعي: اختيار بحسب التطبيق.

مثال (8.42-15): خلاصة المعطيات: $W_\varepsilon(p,q) = 0.2$، الذاتيّان 0.04 لكلّ. المطلوب: S_ε. الحل: الخطوة 1: $0.2 - 0.02 - 0.02 = 0.16$. النتيجة: 0.16. الربط بالذكاء الاصطناعي: تباعد صحّي.

أخطاء شائعة

- **نسيان طرح حدود الذات:** بلا تصحيح يفقد S معنى المسافة (مُتحيّز).
- **الخلط بين W_ε وS_ε:** أحدهما مُتحيّز والآخر مُصحّح.
- **ظنّ أن $S_\varepsilon = 0$ عموماً:** يساوي الصفر فقط عند التطابق.
- **إهمال حساب $W_\varepsilon(p,p)$:** ثلاث حسابات لا واحدة.
- **اختيار ε كبير جداً:** يُفرغ التباعد من المعنى.

جدول تجميع النظريات

النظرية	العنوان	المعادلة المحوريّة	الرسم
2.42	صياغة كانتوروفيتش	$\min_{\gamma \in \Pi} \int c \, d\gamma$	fig-4201
3.42	ثنائية KR (W1)	$\sup_{\|f\|_L \le 1} \mathbb{E}_p[f] - \mathbb{E}_q[f]$	fig-4202
4.42	الانتظام الإنتروبي	$\gamma^\star = u \, e^{-C/\varepsilon} \, v^\top$	fig-4203
5.42	WGAN	$\max_{\|f\|_L \le 1} \mathbb{E}_{p_d}[f] - \mathbb{E}_{p_g}[f]$	fig-4204
6.42	Brenier و W2	$W_2^2 = \min_T \int \|x - T(x)\|^2 dp$	fig-4205
7.42	تدفّق JKO	$\rho_{n+1} = \arg\min_\rho \frac{1}{2\tau} W_2^2 + \mathcal{F}$	fig-4206
8.42	تباعد Sinkhorn	$S_\varepsilon = W_\varepsilon - \frac{1}{2} W_\varepsilon(p,p) - \frac{1}{2} W_\varepsilon(q,q)$	fig-4207

عشرون تمريناً محلولاً (إجابات موجزة)

١. **(كانتوروفيتش)** $p = q = (0.5, 0.5)$، C هويّة — $\mathrm{OT} = 0$.

٢. **(كتل غير متساوية)** $p = (0.6, 0.4), q = (0.4, 0.6)$ هويّة — 0.2.

٣. **(1D W1)** $q = p$ مُزاحاً 1 — 1.

٤. **(فرق CDF)** مثال (6-2.42) — 0.5.

٥. **(KR ثنائيّ)** $f(x) = 2x$ مدخلات الsup؟ — لا (ثبات ليبنتس 2).

٦. **(KR مثال)** $f = -x$ لـ(5-2.42) — $W_1 = 1$.

٧. **(غيبس)** $C = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \varepsilon = 1$ — $K = \begin{bmatrix} 1 & 0.368 \\ 0.368 & 1 \end{bmatrix}$.

٨. **(Sinkhorn)** $p = q = (0.5, 0.5)$ أوّل تحجيم صفوف — $u = (0.366, 0.366)$.

٩. **(حدّ ε)** $\varepsilon \to \infty$ — $\gamma \to p \otimes q$.

١٠. **(WGAN)** $\lambda = 10, \|\nabla f\| = 1.3$ — GP 0.9.

١١. **(W1 vs JS)** توزيعان منفصلان — JS مشبع، W1 ذو تدرّج مفيد.

١٢. **(W2 نقطيّ)** كتلتان بفاصلة 2 — $W_2 = 2$.

١٣. **(W2 غاوسيّ)** $\Sigma_p = 1, \Sigma_q = 4$ — $W_2 = 1$.

١٤. **(W2 بعد)** $\Sigma_q = \mathrm{diag}(4, 9)$ — $W_2 = \sqrt{5} = 2.236$.

١٥. **(Brenier)** $T = \mathrm{diag}(2, 3)x$ — $\psi = x_1^2 + \frac{3}{2} x_2^2$.

١٦. **(JKO)** $\tau = 0.1, \mu_0 = 1$ جهد $x^2/2$ — $\mu_1 = 0.905$.

١٧. **(JKO تباطُن)** $\Sigma_0 = 4 \to 1$، $\tau = 0.1$ — $\Sigma_1 = 3.456$.

١٨. **(Sinkhorn debias)** $W_\varepsilon = 0.3$ ذاتيّان 0.1 — $S_\varepsilon = 0.2$.

١٩. **(Sinkhorn debias2)** $W_\varepsilon = 0.05$ ذاتيّان 0.02 — 0.03.

٢٠. **(تلخيص)** $p = q$ — $S_\varepsilon = 0, W_2 = 0$.

فهرس الرموز

الرمز	المعنى	أول ورود
γ	خطة النقل	2.42
W_1, W_2	مسافات واسرشتين	6.42 · 3.42
K	نواة غيبس	4.42
u, v	مُعاملات Sinkhorn	4.42
T	خريطة النقل	6.42
ρ_{n+1}	كثافة JKO	7.42
S_ε	تباعد Sinkhorn	8.42

المراجع

- L. Kantorovich, (1942). *On the Transfer of Masses*. Doklady Akademii Nauk.
- C. Villani, (2003). *Topics in Optimal Transportation*. AMS.
- M. Cuturi, (2013). *Sinkhorn Distances: Lightspeed Computation of Optimal Transport*. NeurIPS.
- L. Bottou, S., Chintala, M., Arjovsky, (2017). *Wasserstein GAN*. ICML.
- M. Cuturi, G., Peyré, (2019). *Computational Optimal Transport*. Foundations and Trends.
- F. Santambrogio, (2015). *Optimal Transport for Applied Mathematicians*. Birkhäuser.

القسم VIII

بنى متقدّمة

نبذة عن هذا الجزء

ينتهي الكتاب عند الأفق: بنىً رياضية يدخلها الذكاء الاصطناعي الحديث من بابه الواسع. **الرسوم والشبكات الرسومية** حين تكون البيانات علاقاتٍ لا متجهات، و**التعلّم التعزيزي** حين يتعلّم الوكيل بالتجربة والمكافأة لا بالأمثلة المُعنونة، و**نظرية الألعاب** حين يلتقي عدة وكلاء بمصالح متداخلة — من توازن ناش إلى خوارزميات CFR. ثم نفتح نوافذ أعلى تجريداً: **الطوبولوجيا والتحليل الطوبولوجي للبيانات TDA** حيث تُقاس «الأشكال» بالأعداد البِتّية، و**نظرية الفئات** التي تكشف الأنماط المشتركة بين كل ما سبق — من الانتشار العكسي بوصفه بصريّات، وصولاً إلى **الهندسة التفاضلية** للمتشعّبات: المماسّات، والمقياس، والانحناء، وتعلّم متشعّبات التمثيل. هذه الفصول ليست زينةً ختاميّة؛ إنها مفردات العقد القادم من أبحاث التعلّم الآلي. **فصول الجزء:** الرسوم والشبكات الرسومية · التعلّم التعزيزي · نظرية الألعاب · الطوبولوجيا وTDA · نظرية الفئات · الهندسة التفاضلية.

فصول هذا الجزء

- **الفصل 43.** نظرية الرسوم البيانية والشبكات العصبية البيانية
- **الفصل 44.** التعلم التعزيزي: MDPs ومعادلات بيلمان وحدود العيّنات
- **الفصل 45.** نظرية الألعاب والتعلّم الاستراتيجي
- **الفصل 46.** الطوبولوجيا وتحليل البيانات الطوبولوجي (TDA)
- **الفصل 47.** نظرية الفئات والذكاء الاصطناعي التركيبي
- **الفصل 48.** الهندسة التفاضلية في التعلّم: المتشعّبات والتمثيلات

نظرية الرسوم البيانية والشبكات العصبية البيانية

«المدخلات في العالم كثيراً ما تكون علاقات لا جدائل: الشكل الطبيعيّ لتمثيلها ليس متّجهاً بل رسماً بيانيّاً.»

حتى الآن تناولنا بياناتً منسوجةً في شبكات منتظمة (سلاسل، صور). لكن كثيراً من التطبيقات — الجزيئات، الشبكات الاجتماعيّة، أنظمة التوصية، شبكات الاستيراد — بيانات على رسوم بيانية عامّة. هذا الفصل يبني الرياضيّات اللازمة: مصفوفة التجاور، لابلاسي الرسم وطيفه، التجميع الطيفي، ثمّ يطبّقها على الالتفاف البياني (GCN) وانتباه الرسوم (GAT)، ويقيس حدّ التعبير باختبار وايسباش–ليمان.

سبع نظريات:

- **2.43 تمثيل الرسوم: التجاور والدرجة واللابلاسي** — $L = D - A$، $\mathbf{1}^\top L \mathbf{1} = 0$.
- **3.43 طيف اللابلاسي وطاقة ديريشليت** — $L = U \Lambda U^\top$، $x^\top L x = \sum_{(i,j)\in E} (x_i - x_j)^2$.
- **4.43 التجميع الطيفي** — تقليل القطع الطبيعيّ عبر متجهّات اللابلاسي.
- **5.43 الالتفاف البياني (GCN)** — $H^{(l+1)} = \sigma(\hat{A} H^{(l)} W^{(l)})$.
- **6.43 ثبات التقليب والإزاحة في GNN** — $F(\pi G, \pi X) = \pi F(G, X)$.
- **7.43 نظرية GNN العامة وحدّ WL** — تصاغ GNN كتمرير رسائل؛ تعبيرها $\leq$ اختبار WL.
- **8.43 الانتباه البياني (GAT)** — $\alpha_{ij} = \mathrm{softmax}(\mathrm{LeakyReLU}(a^\top [W h_i \| W h_j]))$.

كلّ نظرية تتبع القالب: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
$G = (V, E)$	رسم بيانيّ	عقد وحواف
A	مصفوفة التجاور	$A_{ij} = 1$ إذا حافة
D	مصفوفة الدرجات	$D_{ii} = \sum_j A_{ij}$ قُطريّة
L	لابلاسي الرسم	$L = D - A$
$N(v)$	جيران v	عقد متجاورة
n, m	عدد العقد/الحواف	$n = \|V\|, m = \|E\|$

الاتفاقيات: نبدأ برسوم غير موجّهة بسيطة غير مرجّحة؛ التعميم مرجّح/موجّه يُذكر صراحةً. كلّ المعادلات في كتل LTR.

صياغة رسمية: لرسم غير موجّه $G = (V, E)$ غير مرجّح، تُعرَّف مصفوفة التجاور من L and degree:

$$A_{ij} = \begin{cases} 1, & \{i,j\} \in E \\ 0, & \text{وإلا} \end{cases}, \qquad D = \mathrm{diag}(d_1, \ldots, d_n), \quad d_i = \sum_j A_{ij}, \qquad L = D - A \tag{1.43}$$

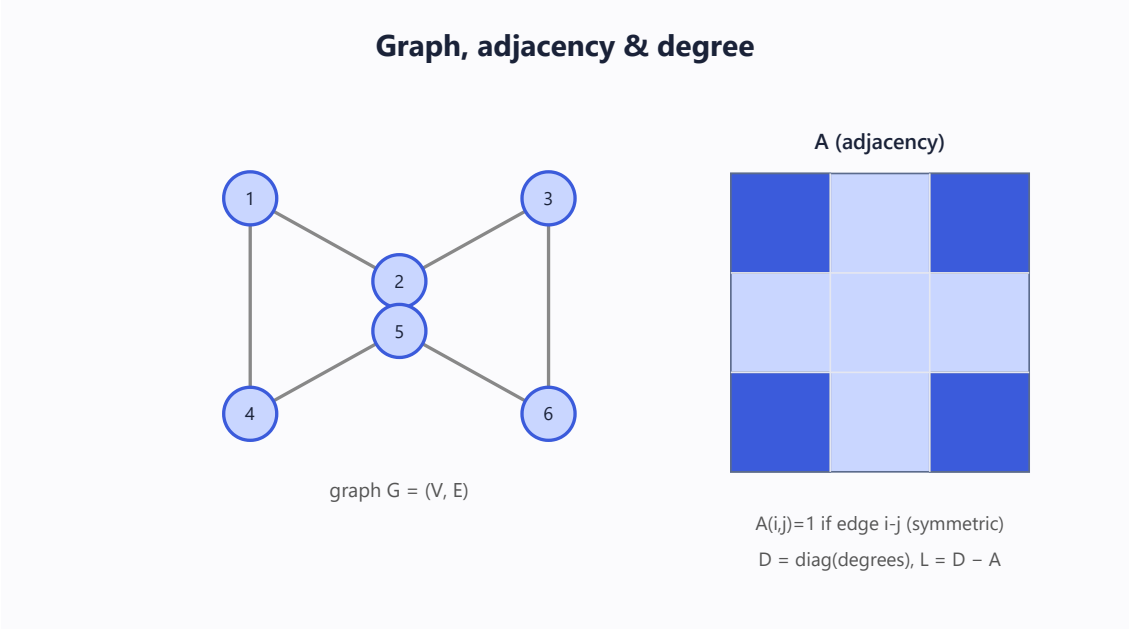
وللابلاسي: مُتماثل، شبه-مُحدَّد الإيجابيّة (PSD)، ومجموع كلّ صفّ صفر.

جدول الرموز

الرمز	المعنى
d_i	درجة العقدة i
$\mathbf{1}$	متّجه الآحاد
(PSD)	شبه-مُحدَّد الإيجابيّة

الرسم

<figure> الشكل<figcaption> 1.43: رسم بعُقد وحواف، ومصفوفة تجاوره المتماثلة A، ومصفوفة درجاته D



شكل ١٠٤٣: *
تمثيل الرسوم

ولابلاسيّه $L = D - A$.</figcaption></figure>

البرهان

الخطوة 1 (تماثل A): الحافة $\{i, j\}$ غير موجّهة $\Rightarrow A_{ij} = A_{ji} \Rightarrow A = A^\top$. ■

الخطوة 2 (مجموع الصفوف): $(L\mathbf{1})_i = d_i - \sum_j A_{ij} = d_i - d_i = 0 \Rightarrow L\mathbf{1} = 0$. ■

الخطوة 3 (PSD): لأيّ x، $x^\top L x = \sum_{i<j} A_{ij}(x_i - x_j)^2 \geq 0$ (طاقة ديريشليت). ■

خمسة عشر مثالاً محلولاً

مثال (1-2.43): مثلّث K_3 المعطيات: عقد $\{1, 2, 3\}$، حواف كلّ زوج. المطلوب: A وD. الحل: الخطوة 1: $A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$. الخطوة 2: الدرجات كلّها 2 $\Rightarrow D = 2I_3$. النتيجة: $A = J_3 - I_3$، $D = 2I$. الربط بالذكاء الاصطناعي: أصغر رسمٍ مكتمل.

مثال (2-2.43): لابلاسي مثلّث المعطيات: A وD من (1-2.43). المطلوب: L. الحل: الخطوة 1: $L = 2I - A$

$A = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$. النتيجة: $L = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$. الربط بالذكاء الاصطناعي: لابلاسي القاعدة.

مثال (3-2.43): مجموع الصفوف المعطيات: L من (2-2.43). المطلوب: التحقّق من صفر مجموع الصفوف. الحل: الخطوة 1: الصفّ الأوّل $2 - 1 - 1 = 0$؛ بالمثل البقيّة. النتيجة: كلّ صفّ صفر. الربط بالذكاء الاصطناعي: يؤكّد قيمة ذاتيّة صفريّة.

مثال (4-2.43): قيم ذاتيّة لابلاسي المثلّث المعطيات: $L = 3I - J_3$ (من $A = J - I$ و$2I - A$). المطلوب: القيم الذاتيّة. الحل: الخطوة 1: J_3 قيمها $L \Rightarrow 3, 0, 0$ قيمها $3 - 3 = 0$ و$3, 3 - 0 = 3$. النتيجة: $\{0, 3, 3\}$. الربط بالذكاء الاصطناعي: $\lambda_1 = 0 \Rightarrow$ اتّصال.

مثال (5-2.43): طاقة ديريشليت المعطيات: $x = (1, -1, 2)$ على K_3. المطلوب: $x^\top L x$. الحل: الخطوة 1: كلّ حافة فرقها 1: $(1 - (-1))^2 = 4$، $(1 - 2)^2 = 1$، $(2 - (-1))^2 = 9$؛ المجموع 14. النتيجة: $0 \geq 14$. الربط بالذكاء الاصطناعي: تأكيد PSD.

مثال (6-2.43): مسار P_3 المعطيات: عقد $3 - 2 - 1$ (حافتان). المطلوب: A وd_i. الحل: الخطوة 1: $A = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}$؛ الدرجات $1, 2, 1$. النتيجة: $d = (1, 2, 1)$. الربط بالذكاء الاصطناعي: رسم خطّيّ.

مثال (7-2.43): لابلاسي المسار المعطيات: A, d من (6-2.43). المطلوب: L. الحل: الخطوة 1: $L = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix}$. النتيجة: $L = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix}$. الربط بالذكاء الاصطناعي: لابلاسي خطّيّ.

مثال (8-2.43): قيم ذاتيّة للمسار المعطيات: L من (7-2.43). المطلوب: القيم الذاتيّة. الحل: الخطوة 1: $L(P_3) = I + \dots$؛ قيمها $\{0, 1, 3\}$ ($2\cos(k\pi/3)$ مع $+1$). النتيجة: $\{0, 1, 3\}$. الربط بالذكاء الاصطناعي: طيف يعرف البنية.

مثال (9-2.43): ثنائيّ كامل $K_{2,2}$ المعطيات: طرف $\{1, 2\}$ طرف $\{3, 4\}$، حواف بين الطرفين فقط. المطلوب: A والدرجات. الحل: الخطوة 1: $A_{13} = A_{14} = A_{23} = A_{24} = 1$؛ الدرجات كلّها 2. النتيجة: $d_i = 2$ لكلّ. الربط بالذكاء الاصطناعي: رسم ثنائيّ.

مثال (10-2.43): رسم موجّه المعطيات: حواف موجّهة $3 \to 2, 2 \to 1$. المطلوب: هل A متماثلة؟ الحل: الخطوة 1: $A_{12} = 1, A_{21} = 0 \Rightarrow$ غير متماثلة. النتيجة: لا. الربط بالذكاء الاصطناعي: موجّه $\neq$ غير موجّه.

مثال (11-2.43): رسم مرجّح المعطيات: $w_{12} = 0.5, w_{13} = 0.3$. المطلوب: W (مصفوفة الأوزان) والدرجة الموزونة. الحل: الخطوة 1: $W_{12} = 0.5$؛ الدرجة الموزونة للعقدة 1 $0.5 + 0.3 = 0.8$. النتيجة: $d_1^{(w)} = 0.8$. الربط بالذكاء الاصطناعي: تعميم مرجّح.

مثال (12-2.43): اللابلاسي الطبيعيّ المعطيات: $\mathcal{L} = D^{-1/2} L D^{-1/2}$. المطلوب: مدخله لـ$K_3$. الحل: الخطوة 1: $D^{-1/2} = (1/\sqrt{2})I \Rightarrow \mathcal{L} = (1/\sqrt{2})L(1/\sqrt{2}) = \frac{1}{2}L$. النتيجة: $\mathcal{L} = \begin{bmatrix} 1 & -1/2 & -1/2 \\ -1/2 & 1 & -1/2 \\ -1/2 & -1/2 & 1 \end{bmatrix}$ (القطر 1). الربط بالذكاء الاصطناعي: معايرة قيم ذاتيّة في $[0, 2]$.

مثال (13-2.43): حلقات ذاتيّة المعطيات: حافة من عقدة إلى نفسها. المطلوب: أثرها. الحل: الخطوة 1: تضيف 2 إلى القطر في A و1 إلى درجة d_i (بحسب الاصطلاح). النتيجة: تُعدّ اصطلاحاً. الربط بالذكاء الاصطناعي: احترس من الاصطلاح.

مثال (14-2.43): حساب عدد الحواف المعطيات: $A(K_3)$. المطلوب: m من A. الحل: الخطوة 1: مجموع A = 6؛ $m = \frac{1}{2}\sum_{ij} A_{ij} = 3$. النتيجة: $m = 3$. الربط بالذكاء الاصطناعي: ربط المصفوفة بالهيكل.

مثال (15-2.43): خلاصة بخلاصة المعطيات: $\sum_i d_i$ لـK_3. المطلوب: العلاقة بـm. الحل: الخطوة 1: $2m = 2 \times 3 = 6 = 2 + 2 + 2 = \sum d_i$. النتيجة: $\sum d_i = 2m$. الربط بالذكاء الاصطناعي: قاعدة تقليب اليد.

أخطاء شائعة

- **نسيان تماثل A:** في الرسم غير الموجّه $A = A^\top$؛ موجّه يُخالف.
- **الخلط بين D وA:** D قُطريّة للدرجات لا مصفوفة الحواف.
- **نسيان صفر مجموع الصفوف:** يميّز اللابلاسيّ ويضمن $\lambda_1 = 0$.
- **الخلط بين L واللابلاسيّ الطبيعيّ:** $D^{-1/2} L D^{-1/2}$ مختلف.
- **إهمال أن القيمة الذاتيّة الصغرى غير الصفريّة تكشف الاتّصال:** $m_2 > 0 \iff$ اتّصال.

صياغة رسمية: اللابلاسي متماثل شبه-مُحَدَّد الإيجابيّة، لذا يُفكَّك طيفيّاً

$$L = U \Lambda U^\top, \qquad 0 = \lambda_1 \le \lambda_2 \le \cdots \le \lambda_n, \qquad L u_k = \lambda_k u_k \tag{2.43}$$

وطاقة ديريشليت لمتّجه x على حواف الرسم هي الشكل التربيعيّ

$$x^\top L x = \sum_{\{i,j\} \in E} (x_i - x_j)^2 \tag{3.43}$$

وعدد المركب المتّصلة يساوي تعدّد القيمة الذاتيّة 0.

جدول الرموز

الرمز	المعنى
λ_2	قابليّة التوصيل (Fiedler)
u_k	متّجه ذاتيّ معياريّ
$\mathrm{mult}(0)$	تعدّد القيمة الصفريّة = عدد المكوّنات

الرسم

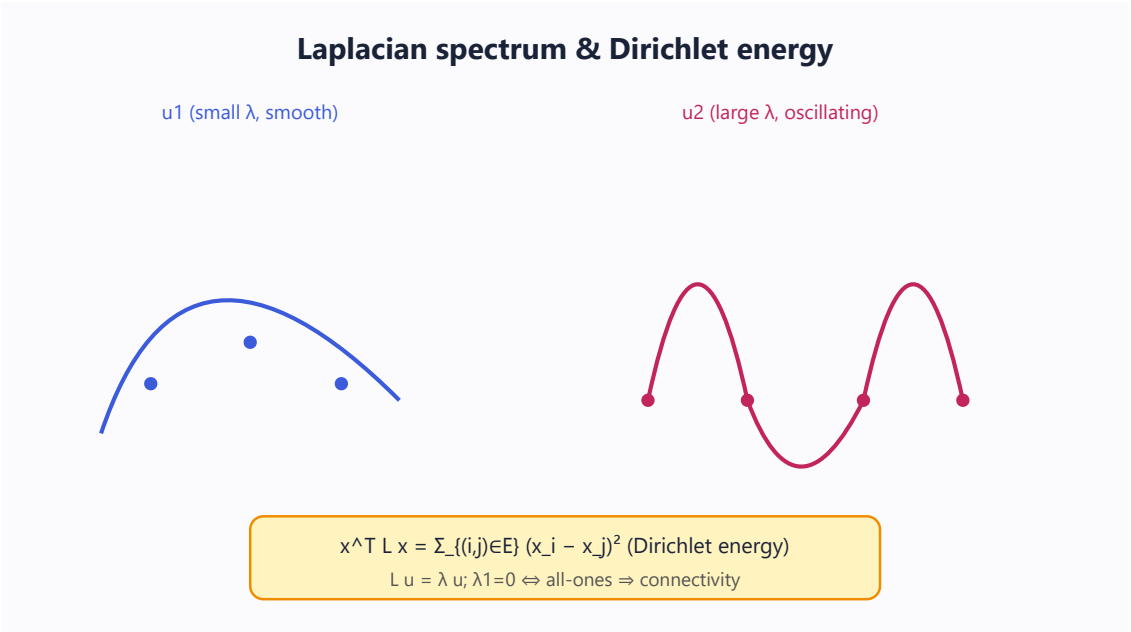
<figure> الشكل<figcaption> 2.43: متّجهات بقيم ذاتيّة صغرى ناعمة؛ الكبرى متذبذبة؛ الطاقة تربط الشكل بالطيف.</figcaption> </figure>

البرهان

الخطوة 1 (النظريّة الطيفيّة): L متماثل حقيقيّ $\Rightarrow$ تفكيك $U \Lambda U^\top$ بقيم ذاتيّة حقيقيّة ومتّجهات معياريّة. ■

الخطوة 2 (الطاقة): $x^\top U \Lambda U^\top x = \sum_k \lambda_k (\langle u_k, x \rangle)^2$؛ وبفكّ الحواف $\sum_{(i,j)} (x_i - x_j)^2$. ■

الخطوة 3 (الصفريّة): x ثابت على كلّ مكوّن متّصل $\Rightarrow$ تعدّدها = عدد المكوّنات. ■



شكل ٢٠٤٣: *
طيف اللابلاسي

خمسة عشر مثالاً محلولاً

مثال (1-3.43): الأثر = مجموع الدرجات المعطيات: $L(K_3)$. المطلوب: $\text{tr}(L)$. الحل: الخطوة 1: $\text{tr}(L) = 2+2+2 = 6$. النتيجة: $2m = 6$. الربط بالذكاء الاصطناعي: ربط الطيف بالحجم.

مثال (2-3.43): مجموع القيم الذاتيّة المعطيات: قيم $L(K_3)$ هي $\{0,3,3\}$. المطلوب: التحقّق من الأثر. الحل: الخطوة 1: $\text{tr}(L) = 6 = 3+3+0$. النتيجة: متّسق. الربط بالذكاء الاصطناعي: الأثر=مجموع القيم.

مثال (3-3.43): متّجه الآحاد المعطيات: u_1 لـ $\lambda_1 = 0$. المطلوب: u_1. الحل: الخطوة 1: $\mathbf{1}/\sqrt{n}$ (تطبيع)؛ $L\mathbf{1} = 0$. النتيجة: $u_1 = \mathbf{1}/\sqrt{3}$. الربط بالذكاء الاصطناعي: نمط ثابت عالميّاً.

مثال (4-3.43): λ_2 للمسار المعطيات: $L(P_3)$ قيمها $\{0,1,3\}$. المطلوب: λ_2 (Fiedler). الحل: الخطوة 1: ثاني أصغر $> 0 \Rightarrow = 1$ مركّب واحد متّصل. النتيجة: $\lambda_2 = 1$. الربط بالذكاء الاصطناعي: دليل الاتّصال.

مثال (5-3.43): متّجه فتلر المعطيات: u_2 لـ P_3. المطلوب: تصوّره. الحل: الخطوة 1: $(1,0,-1) \propto$؛ إشارة يقسم الرسم إلى جزأين عند الوسط. النتيجة: اشارة تقسم. الربط بالذكاء الاصطناعي: أساس التجميع.

مثال (6-3.43): حاصل رايلي المعطيات: $R(u) = \frac{u^\top Lu}{u^\top u}$. المطلوب: لـ $u = (\sin\frac{\pi}{6}, \sin\frac{\pi}{2}, \sin\frac{5\pi}{6})$ على P_3 $(0.5,1,0.5)$. الحل: الخطوة 1: $Lu = (0.5\cdot 1 - 1\cdot 1, -0.5+2-0.5, -1+0.5) = (-0.5,1,-0.5)$؛ $u^\top u = 0.25+1+0.25 = 1.5$؛ $u^\top Lu = -0.25+1-0.25 = 0.5$؛ $R = 0.5/1.5 = 0.333$. النتيجة: $R = \frac{1}{3}$. الربط بالذكاء الاصطناعي: يُصغّره λ_2.

مثال (7-3.43): عدد المكوّنات المعطيات: رسم بثلاث مثلّثات منفصلة. المطلوب: λ_2. الحل: الخطوة 1: ثلاثة مكوّنات $\Rightarrow$ ثلاث قيم صفريّة $\Rightarrow \lambda_2 = 0$. النتيجة: $\lambda_2 = 0$. الربط بالذكاء الاصطناعي: غير متّصل.

مثال (8-3.43): طاقة متّجه المعطيات: $x = (1,1,0)$ على P_3 (حافتا 1-2، 2-3). المطلوب: $x^\top Lx$. الحل: الخطوة 1: $(1-1)^2 + (1-0)^2 = 0+1 = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: تغيّر واحد فقط.

مثال (9-3.43): طاقة مكثّفة المعطيات: $x = (1,-1,1)$ على K_3. المطلوب: $x^\top Lx$. الحل: الخطوة 1: كلّ حافة فرقها 2: $4+4+4 = 12$. النتيجة: 12. الربط بالذكاء الاصطناعي: تذبذب $\Rightarrow$ طاقة عالية.

مثال (10-3.43): الحدّ الأقصى المعطيات: $\lambda_n(K_3) = 3$، $\lambda_n(P_3) = 3$. المطلوب: علاقة بالدرجة. الحل: الخطوة 1: $\lambda_n \le 2\max(d_i)$ (غير طبيعيّ)؛ هنا $2\Delta = 4 \ge 3$. النتيجة: $\lambda_n \le 2\Delta$. الربط بالذكاء الاصطناعي: حدّ عامّ.

مثال (11-3.43): اللابلاسي الطبيعيّ المعطيات: $\mathcal{L} = D^{-1/2}LD^{-1/2}$؛ قيمها في $[0,2]$. المطلوب: قيم K_3. الحل: الخطوة 1: $\mathcal{L} = I - \frac{1}{3}J_3$ (من 12-2.43) قيمها $0, 1, 1$. النتيجة: $\{0,1,1\}$. الربط بالذكاء الاصطناعي: معايرة في $[0,2]$.

مثال (12-3.43): طيف رسالة الدائرة المعطيات: C_4 دور 4. المطلوب: قيم اللابلاسي. الحل: الخطوة 1: $0, 2, 2, 4 \Rightarrow 2 - 2\cos(2\pi k/4)$. النتيجة: $\{0,2,2,4\}$. الربط بالذكاء الاصطناعي: مسافات فوريه على الرسم.

مثال (13-3.43): فوريه بياني المعطيات: $\hat{f} = U^\top f$. المطلوب: هل يُفكّ إلى طاقات لكلّ تردّد؟ الحل: الخطوة 1: نعم؛ $\frac{1}{2}f^\top f = \frac{1}{2}\hat{f}^\top \hat{f}$ يوصّف بالطاقة لكلّ نطاق ترددّيّ. النتيجة: تحليل شبيه بفوريه. الربط بالذكاء الاصطناعي: مرشّحات طيفيّة على الرسم.

مثال (14-3.43): رقم شِيغَر المعطيات: $h = \frac{\text{cut}(S,S^c)}{\min(\text{vol}(S),\text{vol}(S^c))}$؛ $\lambda_2/2 \le h \le \sqrt{2\lambda_2}$. المطلوب: مضمون شيغار لـ$\lambda_2 = 0.6$. الحل: الخطوة 1: $0.3 \le h \le \sqrt{1.2} = 1.095$. النتيجة: $0.3 \le h \le 1.095$. الربط بالذكاء الاصطناعي: ربط الطيف بالقطع.

مثال (15-3.43): خلاصة المعطيات: $\lambda_2 > 0$ صغير. المطلوب: معناه البنيويّ. الحل: الخطوة 1: الرسم متّصل بقطع "زهيد" (عنق زجاجة). النتيجة: قابليّة توصيل ضعيفة. الربط بالذكاء الاصطناعي: يكشف المجموعات.

أخطاء شائعة

- **نسيان أن $\lambda_1 = 0$ دائماً:** متّجه الآحاد دائماً في النواة.
- **الخلط بين عدد القيم الصفريّة وλ_2:** الأولى للمكوّنات، والثانية للاتّصال.
- **الخلط بين L و$\mathcal{L}$ الطبيعيّ:** قيم $\mathcal{L} \in [0,2]$ لا $[0,\infty)$.
- **إهمال أن الطاقة تربط النعومة بالطيف:** فرق قيم العقد الكبير يعني طاقة عالية.
- **الظنّ أن λ_2 يكشف القطع بدقّة:** يقدّره فقط (شِيغار).

صياغة رسمية: نقسم عقد الرسم لتقليل القطع الطبيعيّ:

$$\min_{A \sqcup B = V} \text{Ncut}(A,B) = \text{cut}(A,B)\left(\frac{1}{\text{vol}(A)} + \frac{1}{\text{vol}(B)}\right) \tag{4.43}$$

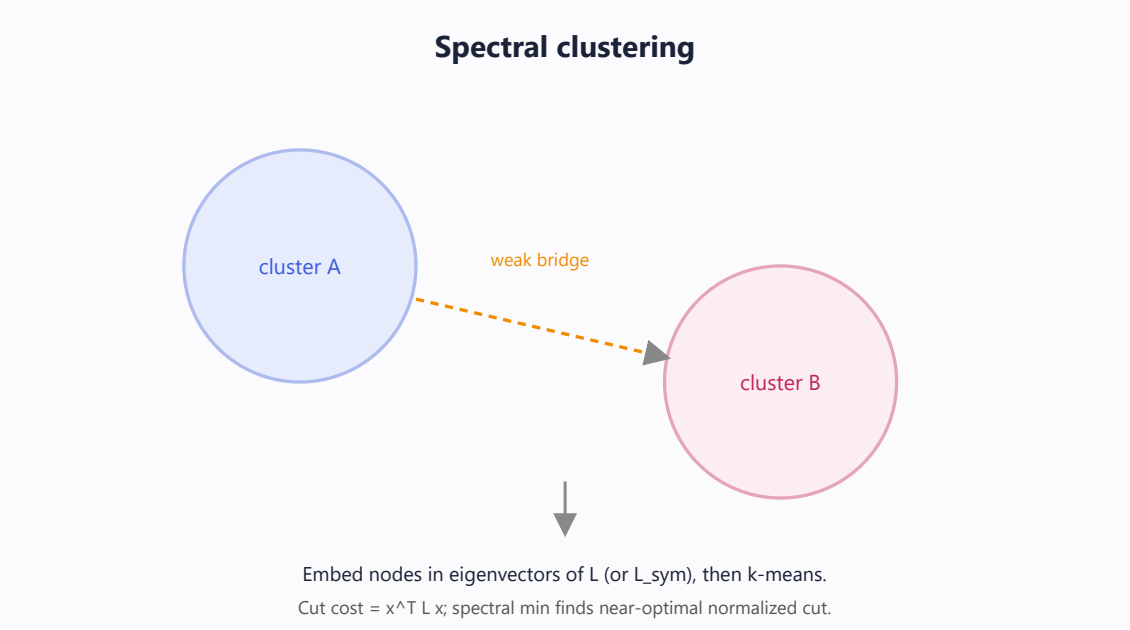
وتُرخَّى بمتّجه المؤشّر الحقيقيّ $y \in \{a,b\}^n$ إلى مشكلة قيم ذاتيّة في $\mathcal{L}$، نأخذ أصغر k متّجهات غير تافهة، نُضمّن العقد، ثمّ k-means.

جدول الرموز

الرمز	المعنى
$\text{cut}(A,B)$	وزن الحواف القاطعة
$\text{vol}(S)$	مجموع درجات S
y	مؤشّر الانتماء (مُرخّى)

الرسم

<figure> الشكل<figcaption> 3.43: تضمين العقد في متّجهات $\mathcal{L}$ يفصل العنقد المتّصلة بقوّة عن



شكل ٣.٤٣: *
التجميع الطيفي

غيرها.</figcaption> </figure>

البرهان

الخطوة 1 (صعوبة NP): تقسيم الرسم الأدنى مشكلة NP-hard؛ لا حلّ متعدّد الحدود. ■

الخطوة 2 (الترخيص): نُرخّي $y \in \{a, b\}$ إلى $y \in \mathbb{R}^n$ مع $y^\top D\mathbf{1} = 0$ ⇒ متّجهات ذاتية. ■

الخطوة 3 (استعادة المنفصل): نُضمّن بأصغر k متّجهات غير تافهة ونُجمّع بـk-means؛ يلتقط بنية المجموعات. ■

خمسة عشر مثالاً محلولاً

مثال (1-4.43): مركّبان منفصلان المعطيات: مثلّثان بلا حافة بينهما. المطلوب: λ_2. الحل: الخطوة 1: مكوّنان ⇒ قيمتان صفريّتان ⇒ $\lambda_2 = 0$. النتيجة: $\lambda_2 = 0$. الربط بالذكاء الاصطناعي: تقسيم تافه ظاهر.

مثال (2-4.43): متّجه فتلر يقسم المعطيات: u_2 بإشارة موجبة على المثلّث الأوّل وسالبة على الثاني. المطلوب: القطع. الحل: الخطوة 1: إشارة u_2 تفصل المجموعتين تماماً. النتيجة: تقسيم صحيح. الربط بالذكاء الاصطناعي: تلقائيّ.

مثال (3-4.43): تضمين ثنائيّ المعطيات: نأخذ u_2, u_3. المطلوب: كيف نفصل المجموعتين؟ الحل: الخطوة 1: قيم المجموعة أ في ربع، ب في آخر؛ k-means يفصلهما. النتيجة: فصل خطّي. الربط بالذكاء الاصطناعي: كتل قابلة للفصل.

مثال (4-4.43): حساب قطع صغير المعطيات: حافة واحدة $\{2, 5\}$ بين عنقدتين، حواف كثيفة داخل كلّ عنقود. المطلوب: cut لهذا القسم. الحل: الخطوة 1: حافة قاطعة واحدة ⇒ cut $= 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: أقلّ حواف قاطعة.

مثال (43.4-5): حجم المجموعة المعطيات: عقد درجاتها $3, 3, 3$ في S؛ و$2, 2$ خارجها. المطلوب: $\text{vol}(S)$. الحل: الخطوة 1: $3 + 3 + 3 = 9$. النتيجة: 9. الربط بالذكاء الاصطناعي: حجم موزون.

مثال (43.4-6): القطع الطبيعيّ المعطيات: $\text{cut} = 1$، $\text{vol}(S) = 9$، $\text{vol}(S^c) = 5$. المطلوب: Ncut. الحل: الخطوة 1: $1 \times (1/9 + 1/5) = 1 \times (0.111 + 0.2) = 0.311$. النتيجة: 0.311. الربط بالذكاء الاصطناعي: يفضّل الأجزاء المتوازنة.

مثال (43.4-7): مقارنة أجزاء المعطيات: قسم أ $\text{Ncut} = 0.311$؛ قسم ب $\text{cut} = 1$، $\text{vol} = 2, 20$. المطلوب: أيّهما أفضل؟ الحل: الخطوة 1: ب: $1 \times (1/2 + 1/20) = 0.55$؛ أ أصغر. النتيجة: أ أفضل. الربط بالذكاء الاصطناعي: Ncut متوازن.

مثال (43.4-8): لماذا ليس k-means على الميزات؟ المعطيات: عقد بميزات متشابهة لكنها في مجتمعتين مختلفتين. المطلوب: علّل نجاح الطيف. الحل: الخطوة 1: البنية ليست في الميزات بل في الروابط؛ الطيف يلتقط الروابط. النتيجة: البنية العلائقيّة. الربط بالذكاء الاصطناعي: تفوّق على الميزات.

مثال (43.4-9): رسمٍ بحلقة ضعيفة المعطيات: عنقدتان متّصلتان بحافة واحدة (عنق زجاجة). المطلوب: متوقّع λ_2. الحل: الخطوة 1: صغير جدّاً (قابلية توصيل ضعيفة)؛ u_2 يكشف مفترق العنق. النتيجة: λ_2 صغير. الربط بالذكاء الاصطناعي: عنق الزجاجة.

مثال (43.4-10): اختيار k المعطيات: فجوة كبيرة بين λ_{k+1} وλ_k. المطلوب: كيف نُقدّر عدد المجموعات؟ الحل: الخطوة 1: نختار k نقطة الجداء الزاوية؛ الفجوة تشير لعدد المجموعات. النتيجة: فجوة الطيف. الربط بالذكاء الاصطناعي: اختيار تلقائيّ.

مثال (43.4-11): تصحيح الدرجة المعطيات: عقدة عالية الدرجة تهيمن. المطلوب: فائدة $\mathcal{L}$ الطبيعيّ. الحل: الخطوة 1: $\mathcal{L}$ يعاير بالدرجات $\Rightarrow$ يمنع هيمنة العقد عالية الدرجة. النتيجة: تجميع أكثر عدالة. الربط بالذكاء الاصطناعي: تطبيع درجة.

مثال (43.4-12): ترتيب المتّجهات المعطيات: $\lambda_1 < \lambda_2 < \lambda_3 < \dots$. المطلوب: أيّ نتجاهل؟ الحل: الخطوة 1: نتجاوز u_1 (ثابت) ونبدأ من u_2. النتيجة: $u_2, u_3, \dots$. الربط بالذكاء الاصطناعي: تخطّي التافه.

مثال (43.4-13): تعقيد الحساب المعطيات: تفكيك كامل $O(n^3)$؛ لوبّيغ $O(nm)$. المطلوب: الأفضل للرسوم الكبيرة. الحل: الخطوة 1: طرق لانكوزوس التقريبيّة $O(mk)$ تقريباً. النتيجة: لانكوزوس. الربط بالذكاء الاصطناعي: قابلية توسّع.

مثال (43.4-14): مثاليّة التجميع المعطيات: مجموعتان متطابقتان. المطلوب: Ncut بعد التيمّل الحتميّ. الحل: الخطوة 1: يميل إلى صفر إذا كان الفصل مثاليّاً. النتيجة: يقارب الصفر. الربط بالذكاء الاصطناعي: حدّ مثاليّ.

مثال (43.4-15): خلاصة المعطيات: رسم بعنق زجاجة واضح. المطلوب: سلوك الطيف. الحل: الخطوة 1: λ_2 صغير؛ u_2 يفصل عند العنق. النتيجة: يُكشف مفترق العنق. الربط بالذكاء الاصطناعي: كشف البنية.

أخطاء شائعة

- **نسيان تخطّي u_1:** هو ثابت بلا معلومة تقسيم.
- **الخلط بين cut وNcut:** Ncut يعاير بالحجم.
- **الظنّ أن التجميع كالk-means على الميزات:** هنا الهيكل من الروابط.
- **إهمال اختيار k:** الفجوة الطيفيّة تُرشد إليه.
- **استخدام L غير الطبيعيّ على رسوم متفاوتة الدرجات:** يُنتج تحيّزاً.

صياغة رسمية: بإضافة حلقات ذاتيّة $\hat{A} = A + I$ وحساب $\hat{D}$ قُطريّة درجاتها، تُعرَّف طبقة الالتفاف البيانيّ بـ

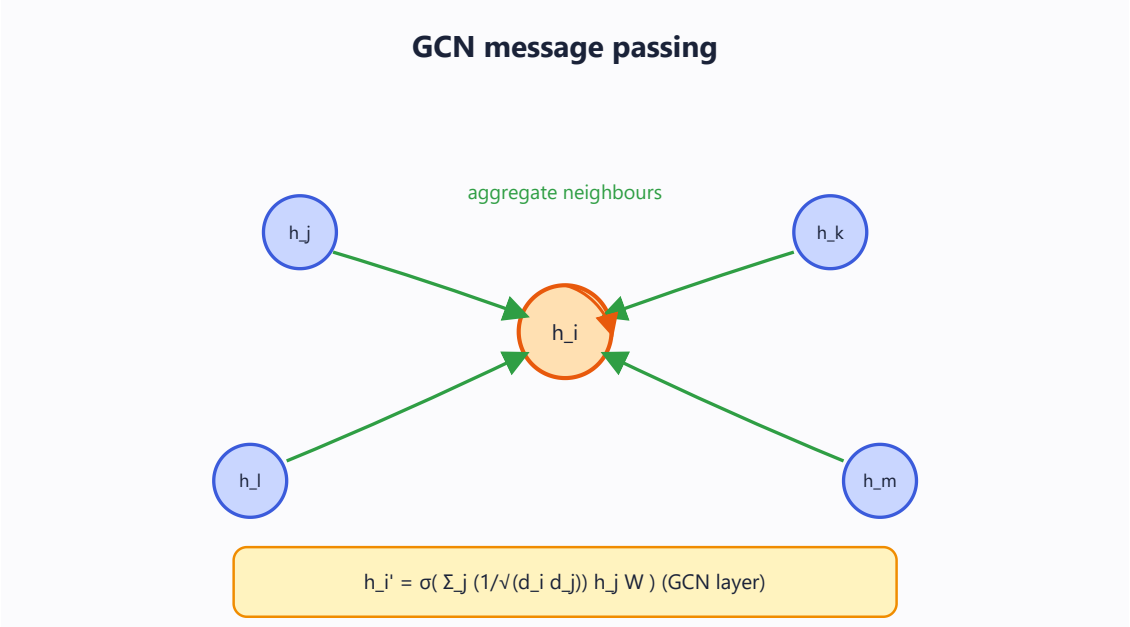
$$H^{(l+1)} = \sigma\big(\hat{A}_{\text{sym}}\, H^{(l)} W^{(l)}\big), \qquad \hat{A}_{\text{sym}} = \hat{D}^{-1/2}\hat{A}\,\hat{D}^{-1/2} \tag{5.43}$$

جدول الرموز

الرمز	المعنى
$H^{(l)}$	مصفوفة ميزات الطبقة l (كلّ صفّ عقدة)
$W^{(l)}$	أوزان الطبقة القابلة للتعلّم
$\hat{A}_{\text{sym}}$	تطبيع تماثليّ للتجاور

الرسم

<figure> الشكل<figcaption> 4.43: كلّ عقدة تُجمّع ميزات جيرانها (والنفس) بوزن معيارى ثمّ تُطبّق تحويلاً خطّيّاً



شكل ٤٠٤٣: *
GCN

وتنشيطاً.<figcaption/> </figure>

البرهان

الخطوة 1 (تمرير الرسائل): العقدة i تجمع $\sum_j \hat{A}_{\text{sym},ij} h_j$ = مزيج معياريّ من جيرانها ونفسها. ■

الخطوة 2 (المعيارى): الوزن من j إلى i هو $\frac{1}{\sqrt{\hat{d}_i \hat{d}_j}}$؛ يحفظ التناظر ويحدّ من سلوك الدرجات. ■

الخطوة 3 (تجميع الطبقات): L طبقات تجمع الجيران حتى مسافة L قفزات (حقل استقبالي). ■

خمسة عشر مثالاً محلولاً

مثال (1-5.43): تطبيع مثلّث المعطيات: K_3، $\hat{A} = A + I = J_3$، $\hat{D} = 3I$. المطلوب: $\hat{A}_{\text{sym}}$. الحل: الخطوة 1: $\hat{A}_{\text{sym}} = (1/\sqrt{3}) J_3 (1/\sqrt{3}) = \frac{1}{3} J_3$. النتيجة: $\frac{1}{3} J_3$ (كلّ الوزن $1/3$). الربط بالذكاء الاصطناعي: تجميع منتظم.

مثال (2-5.43): تجميع عقدة واحدة المعطيات: K_3، ميزات البدء $H^{(0)}$ كلّ صفّ h (متطابقة). المطلوب: تجميع i قبل W. الحل: الخطوة 1: $h = \sum_j \frac{1}{3}h$ (متوسّط المطابق = نفسه). النتيجة: h. الربط بالذكاء الاصطناعي: ثابت تحت التجميع.

مثال (3-5.43): أثر الحلقة الذاتيّة المعطيات: $\hat{A} = A + I$ يضيف i إلى مجموعة الجيران. المطلوب: لماذا؟ الحل: الخطوة 1: كي تحتفظ العقدة بميزاتها الخاصّة أثناء التجميع. النتيجة: حفظ الذات. الربط بالذكاء الاصطناعي: تمنع ضياع الهوية.

مثال (4-5.43): وزن غير متناظر المعطيات: عقدة i درجة 2، جار j درجة 4 (مع الحلقات). المطلوب: الوزن $\hat{A}_{\text{sym},ij}$. الحل: الخطوة 1: $\frac{1}{\sqrt{2 \cdot 4}} = \frac{1}{\sqrt{8}} = 0.354$. النتيجة: 0.354. الربط بالذكاء الاصطناعي: جار عالي الدرجة وزن أقلّ.

مثال (5-5.43): بعد الميزات المعطيات: $n = 64$ عقدة، بُعد ميزة $F = 16$، خرج $F' = 32$. المطلوب: شكل $W^{(0)}$ و$H^{(1)}$. الحل: الخطوة 1: $W^{(0)} \in \mathbb{R}^{16 \times 32}$، $H^{(1)} \in \mathbb{R}^{64 \times 32}$. النتيجة: 64×32. الربط بالذكاء الاصطناعي: مصفوفات ميزات.

مثال (6-5.43): حقل استقباليّ المعطيات: شبكة GCN بطبقتين على مسار P_3. المطلوب: ماذا ترى العقدة الوسطى بعد طبقتين؟ الحل: الخطوة 1: بعد طبقة جيرانها (1،3)؛ بعد طبقتين جيران جيرانها $\Rightarrow$ كلّ الرسم. النتيجة: كلّ العقد. الربط بالذكاء الاصطناعي: انتشار المعلومات.

مثال (7-5.43): تمهيد مفرط (over-smoothing) المعطيات: 20 طبقة GCN. المطلوب: سلوك $H^{(l)}$. الحل: الخطوة 1: التجميع المتكرّر يقارب المتوسّط العالميّ $\Rightarrow$ كلّ العقد تتشابه. النتيجة: تشابه كارثيّ. الربط بالذكاء الاصطناعي: حدّ للعمق.

مثال (8-5.43): تفسير طيفي المعطيات: $\hat{A}_{\text{sym}}$ تشابه قريب من $I - \mathcal{L}$. المطلوب: ماذا يعني التجميع؟ الحل: الخطوة 1: يشبه مرشّحًا منخفض التمرير (يمحو التردّدات العالية/التقلّبات). النتيجة: تنعيم شبيه بطيف. الربط بالذكاء الاصطناعي: ربط بـ(3.43).

مثال (9-5.43): مقارنة بـMLP المعطيات: MLP يتعامل كلّ عقدة منفردة. المطلوب: ميزة GCN. الحل: الخطوة 1: GCN يشارك البنية العلائقيّة $\Rightarrow$ أوزان أقلّ وعموميّة أعلى. النتيجة: مشاركة بنيويّة. الربط بالذكاء الاصطناعي: انتظام بنيويّ.

مثال (10-5.43): تنويعات التطبيع المعطيات: $\hat{D}^{-1/2}\hat{A}\hat{D}^{-1/2}$ مقابل $\hat{D}^{-1}\hat{A}$ (walk). المطلوب: الفرق. الحل: الخطوة 1: الأوّل تماثليّ (كثير الحدود)، والثاني مشي عشوائيّ (walk). النتيجة: مرشّحات مختلفة. الربط بالذكاء الاصطناعي: اختيار التطبيع.

مثال (11-5.43): مشاركة الأوزان المعطيات: $W^{(l)}$ واحدة لكلّ العقد. المطلوب: عدد معاملات طبقة. الحل: الخطوة 1: $F \cdot F'$ (لا يعتمد على n) $\Rightarrow$ قليل. النتيجة: FF'. الربط بالذكاء الاصطناعي: كفاءة معاملات.

مثال (12-5.43): تعقيد الطبقة المعطيات: مصفوفة تجاور متناثرة بـ$2m$ غير-صفرية. المطلوب: تعقيد التجميع. الحل: الخطوة 1: $O(mFF')$ للتناثر (لا n^2). النتيجة: خطّيّ في الحواف. الربط بالذكاء الاصطناعي: قابل للتوسّع.

مثال (13-5.43): التنشيط غير الخطّي المعطيات: $\sigma = \text{ReLU}$ بين الطبقات. المطلوب: لماذا؟ الحل: الخطوة 1: بلا تنشيط تسقط الطبقات الخطّية $\Rightarrow$ عمق بلا فائدة. النتيجة: لا خطّيّة ضروريّة. الربط بالذكاء الاصطناعي: قوّة التعبير.

مثال (14-5.43): تصنيف عقد المعطيات: خرج GCN يعطي احتمالات أصناف لكلّ عقدة. المطلوب: طبقة أخيرة. الحل: الخطوة 1: Softmax خطّيّ فوق التضمين النهائيّ. النتيجة: توقّع صنف لكلّ عقدة. الربط بالذكاء الاصطناعي: تصنيف على الرسوم.

مثال (15-5.43): خلاصة المعطيات: K_3، $H^{(0)} = I_3$، $W = I$. المطلوب: $H^{(1)}$ (بلا تنشيط). الحل: الخطوة 1: $H^{(1)} = \frac{1}{3}J_3 \cdot I = \frac{1}{3}J_3$ (كلّ صفّ مطابق للمتوسّط). النتيجة: صفوف متطابقة. الربط بالذكاء الاصطناعي: تجميع يوحّد الميزات.

أخطاء شائعة

- **نسيان الحلقة الذاتيّة:** بلا $\hat{A} = A + I$ لا تُحفظ ميزات العقدة.
- **الخلط بين التطبيع التماثليّ والمشي:** $\hat{D}^{-1/2}$ مقابل $\hat{D}^{-1}$.
- **تجاهل التمهيد المفرط:** عمق GCN محدود (عادةً 2-4 طبقات).
- **الظنّ أن GCN = GNN:** إنّها حالة تمرير رسائل خاصّة.
- **نسيان أن W لا يعتمد على n:** ثبات غير معتاد لكن سمة مهمّة.

صياغة رسمية: لنمط ترتيب (permutation) $\Pi \in \mathbb{R}^{n \times n}$ π يُعيد ترقيم العقد، فإنّ شبكات تمرير الرسائل "متكافئة" على مستوى العقد:

$$F(\pi(G),\ \pi(X)) = \pi\, F(G, X) \tag{6.43}$$

أمّا قراءة الرسم الكلّيّة (pooling) فهي "ثابتة" (invariant): $\text{read}(G, X) = \text{read}(\pi G, \pi X)$.

جدول الرموز

الرمز	المعنى
π	تبديل ترقيم العقد
equivariance	الإزاحة تتبع الترتيب
invariance	الثبات كلّياً

الرسم

<figure> الشكل<figcaption> 5.43: نفس الرسم بترقيم مختلف؛ مخرجات العقد تُبدَّل بالمقابل (إزاحة)، والقراءة الكلّيّة لا تتغيّر (ثبات).</figcaption> </figure>

البرهان

الخطوة 1 (ترتيب-ثبات التجميع): تمرير الرسائل يجمع على $\mathcal{N}(v)$ بمجموع (لا مرتب)، والوزن W مشترك $\Rightarrow$ لا يعتمد على ترتيب الجيران. ■

الخطوة 2 (الإزاحة): إعادة الترقيم تُبدّل العقد $\Rightarrow$ المخرجات تُبدّل بالمقابل، لا تتغيّر قيماً. ■

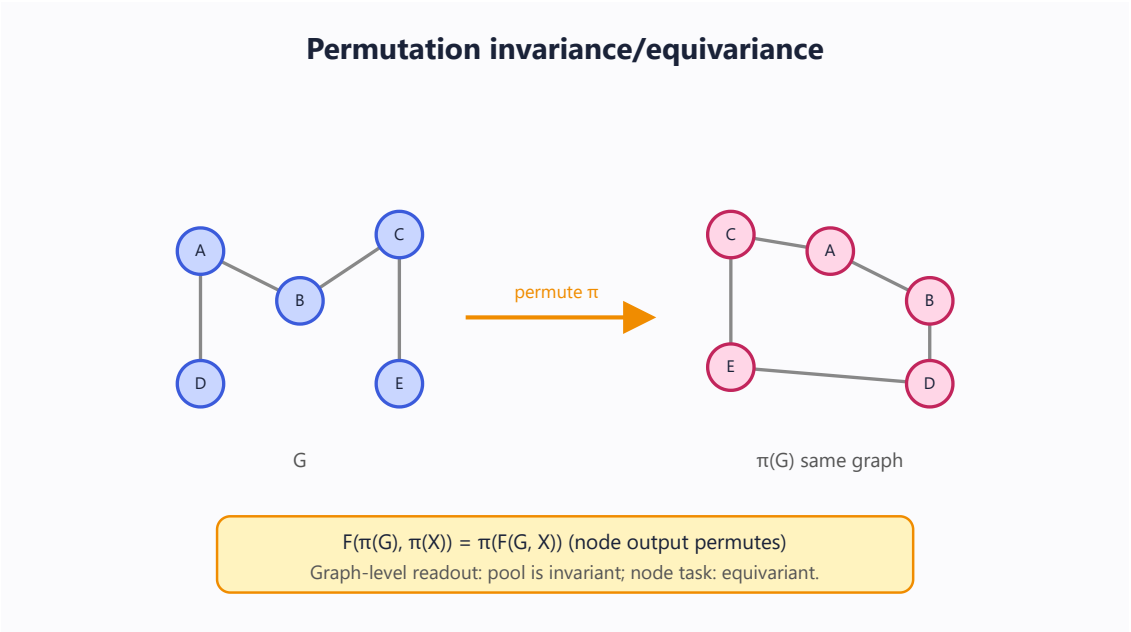
الخطوة 3 (الثبات الكلّيّ): عملية جمع/تجميع على كلّ العقد (sum/mean/max) ثابتة تحتّ التبديل. ■

خمسة عشر مثالاً محلولاً

مثال (6.43-1): قراءة جمعيّة المعطيات: خرج عقد (بعد GNN) $(1, 2, 3)$ =. المطلوب: قراءة المجموع قبل/بعد تبديل $1 \leftrightarrow 2$. الحل: الخطوة 1: قبل: $6 = 3 + 2 + 1$؛ بعد التبديل الميزات $(2, 1, 3)$، المجموع 6 =. النتيجة: 6 (ثابت). الربط بالذكاء الاصطناعي: جمع ثابت.

مثال (6.43-2): متوسط ثابت المعطيات: نفس الميزات. المطلوب: المتوسّط قبل/بعد التبديل. الحل: الخطوة 1: $6/3 = 2$ قبل؛ $6/3 = 2$ بعد. النتيجة: 2 (ثابت). الربط بالذكاء الاصطناعي: mean ثابت.

مثال (6.43-3): إزاحة العقد المعطيات: تبديل $1 \leftrightarrow 2$، topology ثابتة. المطلوب: علاقة مخرجات h'_i. الحل: الخطوة 1: $h'_2 = h'_{1\pi}$ و $h'_1 = h'_{2\pi}$؛ أيّ π-تبديل للمخرجات. النتيجة: إزاحة. الربط بالذكاء الاصطناعي: equivariance العقد.



شكل ٥.٤٣: *
ثبات التبديل

مثال (4-6.43): تمثيل غير متكافئ المعطيات: نرتّب ميزات العقد ترتيباً ضمنيّاً ثمّ نغذّي MLP. المطلوب: هل يظلّ ثابتاً؟ الحل: الخطوة 1: لا، الترتيب الاضطراري يعتمد على الترقيم $\Rightarrow$ لا ثبات. النتيجة: غير ثابت. الربط بالذكاء الاصطناعي: يحتاج بنية تعامل متكافئة.

مثال (5-6.43): رسمان متماثلان المعطيات: G و$\pi(G)$ isomorphic. المطلوب: هل يتساوى التوقّع؟ الحل: الخطوة 1: نعم، الإزاحة $\Rightarrow$ بعد القراءة الكلّيّة القيمة نفسها. النتيجة: يتساويان. الربط بالذكاء الاصطناعي: عموميّة.

مثال (6-6.43): ثباتٍ وسيطة العقد المعطيات: نضيف انحيازاً ثابتاً يُضاف لكلّ عقدة. المطلوب: أثرها. الحل: الخطوة 1: الوزن السيادي يتبع التبديل $\Rightarrow$ يظلّ متكافئاً. النتيجة: متكافئ. الربط بالذكاء الاصطناعي: امتداد.

مثال (7-6.43): مشاركة ثابتة المعطيات: نستخدم وزن خاصّ لكلّ عقدة W_i. المطلوب: هل يبقى متكافئاً؟ الحل: الخطوة 1: لا، W_i يرتبط بترقيم محدّد $\Rightarrow$ يكسر الإزاحة. النتيجة: غير متكافئ. الربط بالذكاء الاصطناعي: ثبات الوزن المشترك.

مثال (8-6.43): pooling max المعطيات: ميزات $(2, 5, 5)$. المطلوب: قراءة max قبل/بعد تبديل. الحل: الخطوة 1: قبل 5، بعد $(5, 5, 2) \Rightarrow 5$. النتيجة: 5 (ثابت). الربط بالذكاء الاصطناعي: max ثابت.

مثال (9-6.43): إزاحة الحواف المعطيات: حافة ذات وزن α بين عقدتين. المطلوب: هل يتغيّر α بإعادة الترقيم؟ الحل: الخطوة 1: لا، يعتمد على الثنائيّ (h_i, h_j) لا على الترقيم. النتيجة: ثابت. الربط بالذكاء الاصطناعي: أساس GAT.

مثال (10-6.43): دفعة رسوم المعطيات: دفعة من B رسوم مختلفة الأحجام. المطلوب: كيف نجمع القراءات؟ الحل: الخطوة 1: نجمّع متّجهات كلّ رسم في مصفوفة، القراءة الكلّيّة ثابتة لكلّ رسم. النتيجة: B قراءات. الربط بالذكاء الاصطناعي: قابل للدفعات.

مثال (11-6.43): تعميم تدريبيّ المعطيات: تدريب على رسوم صغيرة يعطي نتائج عامّة. المطلوب: فائدة الثبات. الحل: الخطوة 1: يضمن عموميّةً لأنّ الخطأ لا يعتمد على الترقيم. النتيجة: تعميم أقوى. الربط بالذكاء الاصطناعي: قدرة نقل.

مثال (12-6.43): تعزيز البيانات المعطيات: نولّد $\pi(G)$ كعيّنة إضافيّة. المطلوب: الفائدة. الحل: الخطوة 1: لا فائدة

تدريبية؛ إعادة الترقيم بلا معلومة جديدة. النتيجة: بلا فائدة. الربط بالذكاء الاصطناعي: التكافؤ وحده يكفي.

مثال (13-6.43): الانتباه الثابت المعطيات: GAT يحسب α_{ij} من $[Wh_i \| Wh_j]$. المطلوب: هل يتّبع الإزاحة؟ الحل: الخطوة 1: نعم؛ التبديل يُبدّل الجيران والمخرجات معاً. النتيجة: متكافئ التبديل. الربط بالذكاء الاصطناعي: GAT متكافئ.

مثال (14-6.43): تعقيد التحقّق المعطيات: n عقدة، نختبر k تبديلات. المطلوب: كلفة التحقّق العدديّ. الحل: الخطوة 1: تبليغ مشابه لتطبيق GNN مرة أخرى $\Rightarrow k\times$ التطبيع. النتيجة: $O(k\,m\,FF')$. الربط بالذكاء الاصطناعي: اختبار عمليّ.

مثال (15-6.43): خلاصة المعطيات: G مركّب منفصل ومربوط. المطلوب: أثر التبديل على القراءة الكلّيّة. الحل: الخطوة 1: لا شيء؛ القيمة لا تتغيّر أبداً. النتيجة: ثابت تامّ. الربط بالذكاء الاصطناعي: قراءة عامّة.

أخطاء شائعة

- **الخلط بين الإزاحة والثبات:** للعقد إزاحة، وللرسم ثبات.
- **استخدام أوزان خاصّة بالعقدة:** يكسر الإزاحة (إلا لـpositional ثابت).
- **نسيان أن الترتيب يتبع الترقيم:** المخرج ليس ترتيبيّاً بل مرتبط بالعقدة.
- **الظنّ أن كلّ GNN متكافئ:** يجب أن يكون التجميع ترتيب-ثابت.
- **خلط هويّة التبديل مع WL:** WL للأعضاء وisomorphism؛ equivariance خاصّة تدريب.

صياغة رسمية: تُصاغ شبكات GNN العامّة كاجتياب رسائل متكرّر:

$$m_v^{(l)} = \bigoplus_{u \in \mathcal{N}(v)} M\big(h_v^{(l-1)}, h_u^{(l-1)}, e_{uv}\big), \qquad h_v^{(l)} = U\big(h_v^{(l-1)}, m_v^{(l)}\big) \tag{7.43}$$

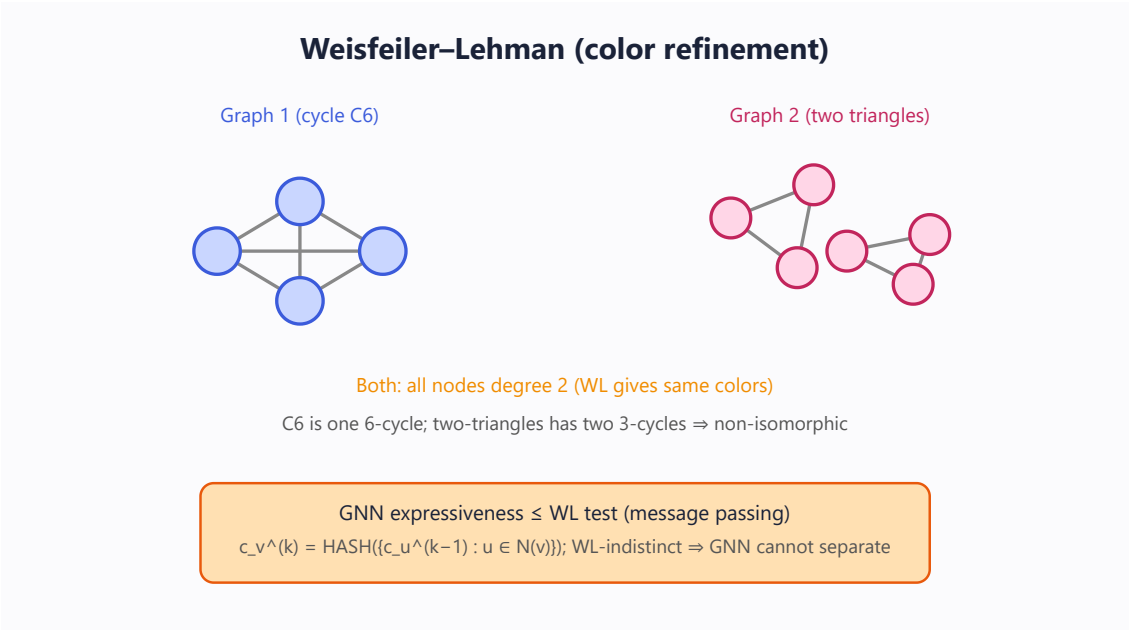
وحدّ التعبير: دقّة GNN في التمييز بين رسمين لا تتجاوز اختبار ويسباشير–ليمان (WL).

جدول الرموز

الرمز	المعنى
M	دالّة الرسالة
U	دالّة تحديث العقدة
WL	اختبار تصفية الألوان

الرسم

<figure> الشكل<figcaption> 6.43: دورة التلوين تصفّر ألوان العقد بجيرانها؛ WL لا يفرّق C6 عن مثلّثين رغم أنهما غير متماثلين.</figcaption> </figure>



شكل ٦٠٤٣: * اختبار WL

البرهان

الخطوة 1 (تكافؤ WL): كلّ جولة GNN توافق جولة تلوين WL؛ التجميع ≠ تجزئة متعدّدة الألوان. ■

الخطوة 2 (مقياس تفكيك): إن كانت M, U حقينّتين (injective) على المجموعات، تبلغ GNN حدّ WL تماماً (Xu 2019). ■

الخطوة 3 (حدّ الدقّة): إذا لم يفرّق WL رسمين، فلا تفرّقهما GNN بمشاركة أوزان. ■

خمسة عشر مثالاً محلولاً

مثال (43.7-1): تلوين WL الأوّلي المعطيات: رسم غير مرجّح بلا ميزات عقد. المطلوب: اللون الأوّل لكلّ عقدة. الحل: الخطوة 1: كلّ العقد بلون موحّد (ولا ميزات). النتيجة: لون واحد. الربط بالذكاء الاصطناعي: بنيويّ صرف.

مثال (43.7-2): جولة تصفية المعطيات: $c^{(0)}(v)$ موحّدة. المطلوب: $c^{(1)}(v)$. الحل: الخطوة 1: $c^{(1)} \propto$ درجة العقدة (عدد الجيران). النتيجة: يُفرّق الدرجات. الربط بالذكاء الاصطناعي: يدرك الدرجة.

مثال (43.7-3): C_6 مقابل مثلّثين المعطيات: دورة 6-عقد، مقابل مثلّثين منفصلين (6 عقد). المطلوب: هل يفرّقهما WL؟ الحل: الخطوة 1: كلاهما منتظمان درجة 2 $\Rightarrow$ كلّ جولات WL تُنتج لوناً واحداً. النتيجة: لا يفرّق. الربط بالذكاء الاصطناعي: عمى WL.

مثال (43.7-4): كلاهما غير متماثل المعطيات: C_6 دورة واحدة؛ المثلّثان جذرين منفصلين. المطلوب: تحقّق من عدم التماثل. الحل: الخطوة 1: C_6 متّصل دائماً؛ المثلّثان ينفصلان بحذف عقدة مختلفة. النتيجة: غير متماثلين. الربط بالذكاء الاصطناعي: WL ممرّ حتّى.

مثال (43.7-5): عمق = جولات المعطيات: GCN بعمق 3. المطلوب: ماذا يكافئ؟ الحل: الخطوة 1: 3 جولات WL (تلوين حتى المسافة 3 قفزات). النتيجة: WL بطول 3. الربط بالذكاء الاصطناعي: علاقة العمق.

مثال (43.7-6): تجميع حقينيّ المعطيات: تجميع sum مع دالّة حقينيّة. (GIN) المطلوب: مضمون الدقّة. الحل: الخطوة 1: يحقّق حدّ WL تماماً. النتيجة: GIN مثاليّ WL. الربط بالذكاء الاصطناعي: أقصى تعبير.

مثال (7-7.43): متوسط مقابل جمع المعطيات: GCN (متوسط) مقابل GIN (جمع). المطلوب: أيهما أقوى؟ الحل: الخطوة 1: GIN (جمع) أقوى؛ المتوسّط قد يفتقد تمييز (غير حقينيّ). النتيجة: GIN أقوى. الربط بالذكاء الاصطناعي: اختيار التجميع.

مثال (8-7.43): رسم منتظم المعطيات: كلّ العقد درجة k. المطلوب: سلوك WL. الحل: الخطوة 1: كلّ العقد نفس اللون دائماً $\Rightarrow$ WL يفشل كليّاً. النتيجة: عمى كامل. الربط بالذكاء الاصطناعي: حالة صعبة.

مثال (9-7.43): ترميز موضعيّ المعطيات: نضيف خصائص بنيويّة (الدرجة، والمتّجهات الذاتيّة للنابلاسي). المطلوب: هل يكسر حدّ WL؟ الحل: الخطوة 1: نعم؛ ميزات تمييز لكلّ عقدة كسرت العمى. النتيجة: يتجاوز WL. الربط بالذكاء الاصطناعي: خصائص بنيويّة.

مثال (10-7.43): حدود الترميز الموضعيّ المعطيات: المتّجهات الذاتيّة للنابلاسي تعتمد على الترتيب العدديّ. المطلوب: هل يكسر الثبات؟ الحل: الخطوة 1: قد يكسر الإزاحة المتكافئة إن لم يُبنَ بحذر. النتيجة: مقايضة. الربط بالذكاء الاصطناعي: حذر.

مثال (11-7.43): WL عالي الرتبة المعطيات: WLk- يعمل على أزواج العقد. المطلوب: قوّته. الحل: الخطوة 1: أقوى من WL-1 لكنه أعلى كلفة حسابيّة. النتيجة: أقوى وأغلى. الربط بالذكاء الاصطناعي: GNN عالي الرتبة.

مثال (12-7.43): تعقيد WL المعطيات: k جولات، n عقدة. المطلوب: التعقيد. الحل: الخطوة 1: $O(km)$ تقريباً لجولة تلوين. النتيجة: خطّيّ في الحواف. الربط بالذكاء الاصطناعي: عمليّ.

مثال (13-7.43): دقّة WL على البيانات المعطيات: مولّدات حقيقيّة غالباً تمييزها بـWL-1. المطلوب: تكفي GNN العمليّة؟ الحل: الخطوة 1: كثيراً نعم؛ الحدّ نظريّ وليس قيداً عمليّاً. النتيجة: تكفي عمليّاً. الربط بالذكاء الاصطناعي: الحدّ نظريّ لا عمليّ.

مثال (14-7.43): رسائل عالية الترتيب المعطيات: M يعتمد على حافة e_{uv} ومتجهات. المطلوب: التصنيف. الحل: الخطوة 1: يقع تحت إطار تمرير الرسائل ذاته. النتيجة: حالة عامّة. الربط بالذكاء الاصطناعي: تعميم.

مثال (15-7.43): خلاصة المعطيات: تمييز رسمين متماثلين. المطلوب: أقصى ما تبلغه GNN. الحل: الخطوة 1: بقدر ما يميّزه WL؛ لا أكثر. النتيجة: WL-1 كحدّ. الربط بالذكاء الاصطناعي: سقف نظريّ.

أخطاء شائعة

- **الظنّ أن GNN أقوى من WL:** هي على الأكثر بقوّة WL-1.
- **استخدام متوسط يعتقد حدّاً أعلى:** المتوسّط قد يفقد تمييزاً.
- **نسيان أن depth = عدد جولات WL.**
- **الظنّ أن WL-1 يكشف التماثل دائماً:** يفشل على الرسوم المنتظمة.
- **إهمال أن WL-1 يفشل بينما GNN تفشل بالمثل:** الحدّ مشترك.

صياغة رسمية: بدل أوزان تجاور ثابتة، تحسب GAT معامل انتباه لكلّ حافة:

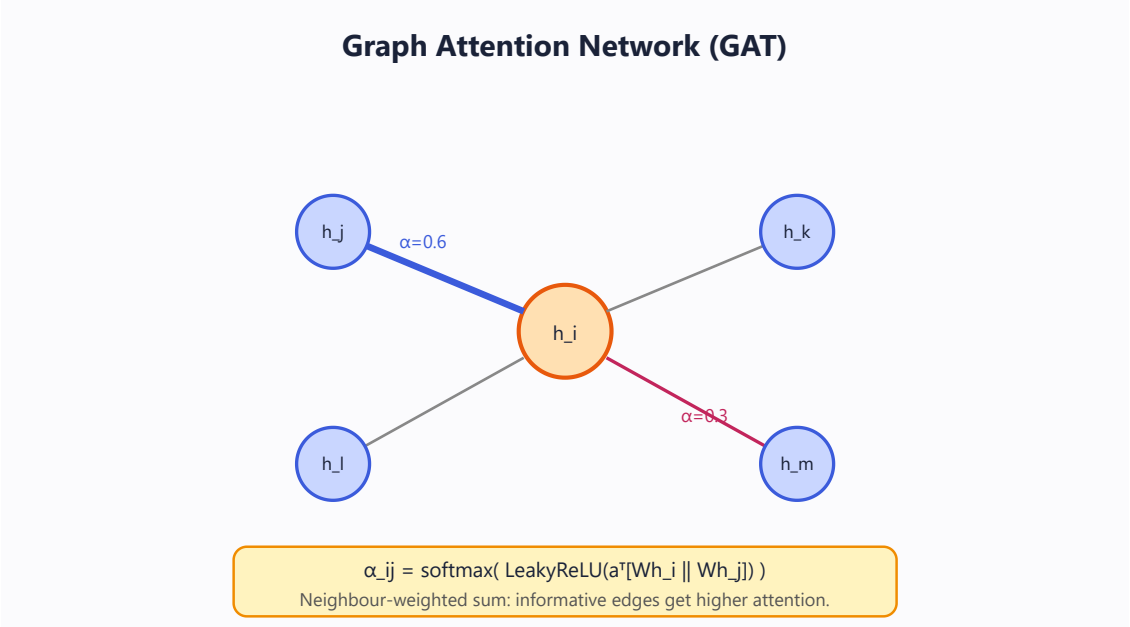
$$\alpha_{ij} = \frac{\exp\big(\mathrm{LeakyReLU}(a^\top [Wh_i \| Wh_j])\big)}{\sum_{k \in \mathcal{N}(i)} \exp\big(\mathrm{LeakyReLU}(a^\top [Wh_i \| Wh_k])\big)}, \qquad h_i' = \sigma\Big(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}\, W h_j\Big) \tag{8.43}$$

جدول الرموز

الرمز	المعنى
a	متّجه أوزان الانتباه
α_{ij}	وزن الانتباه من j إلى i
LeakyReLU	تنشيط بمنحدر سالب صغير

الرسم

<figure> الشكل<figcaption> 7.43: حافة ذات وزن انتباه أعلى (عريضة) تساهم أكثر في تجميع العقدة



شكل ٧.٤٣: *
GAT

الوسطى.</figcaption> </figure>

البرهان

الخطوة 1 (معامل الحافة): نُحوّل $[Wh_i \| Wh_j]$ عبر a وLeakyReLU إلى سجلّ e_{ij}. ■
الخطوة 2 (تطبيع): softmax على جيران i فقط يجعل $\sum_j \alpha_{ij} = 1$. ■
الخطوة 3 (التجميع): المجموع الموزون $\sum_j \alpha_{ij} W h_j$ يميّز الجيران المهمّة؛ رؤوس متعدّدة تلتقط أنماطاً متنوّعة. ■

خمسة عشر مثالاً محلولاً

مثال (8.43-1): معاملات الانتباه المعطيات: جيران i ثلاثة؛ سلوجيّات LeakyReLU لها $0.5, -0.2, 1.0$. المطلوب: α_{ij} (softmax). الحل: الخطوة 1: $\exp(0.5) = 1.649$، $\exp(-0.2) = 0.819$، $\exp(1.0) = 2.718$؛ المجموع 5.186. الخطوة 2: $\alpha = (0.318, 0.158, 0.524)$. النتيجة: $\alpha_j = 0.318, \alpha_k = 0.158, \alpha_l = 0.524$. الربط بالذكاء الاصطناعي: وزن للجار الأهمّ.

مثال (8.43-2): مجموع الأوزان المعطيات: α من (8.43-1). المطلوب: التحقّق من التطبيع. الحل: الخطوة 1: $0.318 + 0.158 + 0.524 = 1.000$. النتيجة: 1. الربط بالذكاء الاصطناعي: softmax مطبّع.

مثال (8.43-3): تجميع موزون المعطيات: $Wh_j = 2, Wh_k = 1, Wh_l = 4$ (سُلّمي)؛ α من (8.43-1).

المطلوب: المجموع. الحل: الخطوة 1: $0.318 \times 2 + 0.158 \times 1 + 0.524 \times 4 = 0.636 + 0.158 + 2.096 = 2.890$. النتيجة: 2.890. الربط بالذكاء الاصطناعي: تجميع مرجّح.

مثال (8.43-4): رأس متعدّد المعطيات: $K = 4$ رؤوس. المطلوب: شكل الخرج. الحل: الخطوة 1: نُجمّع مخرجات الرؤوس $\Rightarrow 4F'$ (بالتوصيل) أو متوسّطها. النتيجة: $4F'$. الربط بالذكاء الاصطناعي: تباين التخصيص.

مثال (8.43-5): مقارنة بـGCN المعطيات: GCN يعطي وزناً ثابتاً $\frac{1}{\sqrt{\hat{d}_i \hat{d}_j}}$؛ GAT يعلمه. المطلوب: الفرق الجوهريّ. الحل: الخطوة 1: GCN ثابت مستقلّ عن الميزات؛ GAT يعتمد على الميّزات. النتيجة: ثابت مقابل متعلَّم. الربط بالذكاء الاصطناعي: مرونة أعلى.

مثال (8.43-6): دور LeakyReLU المعطيات: سجلّ سالب كبير. المطلوب: لماذا لا ؟ReLU الحل: الخطوة 1: ReLU يُصفّر السجلّات السالبة (تدرّج معدوم)؛ LeakyReLU يحتفظ بميل سالب صغير. النتيجة: تدرّج أسلم. الربط بالذكاء الاصطناعي: استقرار الانتباه.

مثال (8.43-7): عدد المعاملات المعطيات: $W \in \mathbb{R}^{F \times F'}$، $a \in \mathbb{R}^{2F'}$ (رأس واحد). المطلوب: العدد. الحل: الخطوة 1: $FF' + 2F' = F'(F+2)$ لكلّ رأس. النتيجة: $F'(F+2)$. الربط بالذكاء الاصطناعي: خفيف نسبيّاً.

مثال (8.43-8): قناع الجيران المعطيات: softmax على $\mathcal{N}(i)$ فقط. المطلوب: أثر العقد غير المتجاورة. الحل: الخطوة 1: وزنها صفر تماماً (لا تُدخل softmax). النتيجة: صفر. الربط بالذكاء الاصطناعي: احترام البنية.

مثال (8.43-9): استقراريّة المعطيات: تهيئات مختلفة لنفس الرسم. المطلوب: هل يختلف α؟ الحل: الخطوة 1: يعتمد على الميزات والتدرّب، قد يختلف لكن البنية الأهمّ ثابتة. النتيجة: قد يختلف. الربط بالذكاء الاصطناعي: مرونة مع ثبات.

مثال (8.43-10): تطبيق استقرائيّ المعطيات: رسم جديد غير مرئٍ أثناء التدريب. المطلوب: هل يعمل ؟GAT الحل: الخطوة 1: نعم، α يُحسب محلّيّاً من الميزات بلا ترقيم ثابت. النتيجة: استقرائيّ. الربط بالذكاء الاصطناعي: قابل للنقل.

مثال (8.43-11): انتباه مُتعلَّم المعطيات: بعد التدريب، وزنٌ عالٍ لحافة "مهمّة". المطلوب: التفسير. الحل: الخطوة 1: النموذج تعلّم أهمّيّة تلك العلاقة للمهمّة. النتيجة: تفسيريّة. الربط بالذكاء الاصطناعي: انتباه قابل للفحص.

مثال (8.43-12): مجموع موزون متنوّع المعطيات: $\alpha = (0.5, 0.3, 0.2)$، ميزات $(1, 10, 100)$. المطلوب: المجموع. الحل: الخطوة 1: $0.5 \times 1 + 0.3 \times 10 + 0.2 \times 100 = 0.5 + 3 + 20 = 23.5$. النتيجة: 23.5. الربط بالذكاء الاصطناعي: الجار الكبير يقود.

مثال (8.43-13): تعقيد GAT المعطيات: m حواف، F، F'. المطلوب: تعقيد الطبقة. الحل: الخطوة 1: حساب $a^\top [Wh_i \| Wh_j]$ لكلّ حافة $O(mF')$، التجميع $O(mF')$. النتيجة: خطّيّ في الحواف. الربط بالذكاء الاصطناعي: قابل للتوسّع.

مثال (8.43-14): تماثل GAT المعطيات: تبديل π. المطلوب: هل يتبع الإزاحة؟ الحل: الخطوة 1: نعم، كحالة GNN فهو متكافئ التبديل (6.43). النتيجة: متكافئ. الربط بالذكاء الاصطناعي: ثبات مضمون.

مثال (8.43-15): خلاصة المعطيات: جار وحيد لـi. المطلوب: α. الحل: الخطوة 1: softmax على عنصر واحد $\Rightarrow \alpha = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: يختزل إلى خطّيّ.

أخطاء شائعة

- **نسيان تطبيع softmax على الجيران فقط:** بلا قناع تدخل كلّ العقد.
- **استخدام ReLU بدل LeakyReLU:** قد يقتل التدرّج على السجلّات السالبة.

- **الخلط بين** $a^\top[Wh_i \| Wh_j]$ **والمعامل:** الأوّل سجلّ، والثاني softmax.
- **نسيان أن الأوزان متعلَّمة من البيانات:** تختلف عن ثابت GCN.
- **إغفال رؤوس متعدّدة:** تكشف أنماطاً متنوّعة تُحسّن التعبير.

جدول تجميع النظريات

النظرية	العنوان	المعادلة المحوريّة	الرسم
2.43	التجاور واللابلاسي	$L = D - A$	fig-4301
3.43	طيف اللابلاسي وديريشليت	$x^\top L x = \sum (x_i - x_j)^2$	fig-4302
4.43	التجميع الطيفي	$\mathcal{L}$ متّجهات $\Rightarrow$ min Ncut	fig-4303
5.43	الالتفاف البيانيّ	$H^{(l+1)} = \sigma(\hat{A}_{\text{sym}} H^{(l)} W^{(l)})$	fig-4304
6.43	ثبات التبديل	$F(\pi G, \pi X) = \pi F(G, X)$	fig-4305
7.43	تمرير الرسائل وWL	رسائل متكرّرة $\leq$ WL	fig-4306
8.43	الانتباه البيانيّ	$\alpha_{ij} = \text{softmax}(a^\top[Wh_i \| Wh_j])$	fig-4307

عشرون تمريناً محلولاً (إجابات موجزة)

١. **(تجاور** K_3**)** $A = ?$ — $\begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$.

٢. **(لابلاسي** K_3**)** $L = ?$ — $\begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$.

٣. **(قيم** K_3**)** الطيف؟ — $\{0, 3, 3\}$.

٤. **(مسار** P_3**)** الدرجات؟ — $(1, 2, 1)$.

٥. **(طاقة)** $x = (1, -1, 2)$ على K_3؟ — 14.

٦. **(اتّصال)** رسم بمكوّنين، λ_2؟ — 0.

٧. **(طبيعيّ** K_3**)** $\mathcal{L}$ قطرها؟ — 1، خارجها $-1/2$.

٨. **(حجم)** $\text{vol}(S)$ لدرجات $3, 3, 3$؟ — 9.

٩. **(Ncut)** $\text{cut} = 1$، أحجام $9, 5$؟ — 0.311.

١٠. **(GCN تطبيع)** K_3 وزن التجميع؟ — $1/3$ لكلّ.

١١. **(GCN وزن)** $d_i = 2, d_j = 4$ (مع الحلقات)؟ — 0.354.

١٢. **(GCN عمق)** طبقتان تغطّيان؟ — مسافة قفزتين.

١٣. **(ثبات)** خرج العقد $(1, 2, 3)$، اقرأ المجموع بعد تبديل؟ — 6.

١٤. **(WL)** هل يفرّق C_6 عن مثلّثين؟ — لا (كلاهما درجة 2).

١٥. **(GAT)** softmax لسلوجيّات $0.5, -0.2, 1.0$؟ — $(0.318, 0.158, 0.524)$.

١٦. **(GAT تجميع)** ميزات $2, 1, 4$ بالأوزان أعلاه؟ — 2.890.

١٧. **(معاملات GAT)** $F = 8, F' = 4$؟ — $4 \times (8 + 2) = 40$.

١٨. **(مجموع درجات)** $\sum d_i$؟ — $2m$.

١٩. **(عدد حواف)** مجموع $A(K_3)$؟ — 3.

٢٠. **(ثبات كامل)** تغيير الترقيم على القراءة الكلّيّة؟ — بلا تغيّر.

فهرس الرموز

الرمز	المعنى	أول ورود
A	مصفوفة التجاور	2.43
D, L	الدرجة واللابلاسي	2.43
λ_2	قابليّة التوصيل (فيدلر)	3.43
Ncut	القطع الطبيعيّ	4.43
$H^{(l)}$	ميزات GCN	5.43
α_{ij}	وزن انتباه GAT	8.43

المراجع

- M. Welling, T., Kipf, (2017). *Semi-Supervised Classfiication with Graph Convolutional Networks*. ICLR.
- J. Bruna, et al. (2014). *Spectral Networks and Locally Connected Networks on Graphs*. ICLR.
- P. Veličković, et al. (2018). *Graph Attention Networks*. ICLR.
- K. Xu, et al. (2019). *How Powerful are Graph Neural Networks?* ICLR.
- J. Leskovec, R., Ying, W., Hamilton, (2017). *Inductive Representation Learning on Large Graphs*. NeurIPS.
- F. Scarselli, et al. (2009). *The Graph Neural Network Model*. IEEE Transactions.

التعلم التعزيزي: MDPs ومعادلات بيلمان وحدود العيّنات

«التعلّم التعزيزيّ ليس تصنيف بيانات ثابتة؛ بل تعلّم بالتفاعل مع بيئة غير مضمونة، وجرت مقيّدة على العائد المستقبليّ.»

بنى التعلّم التي درسناها تعلّم إشرافيّ؛ هنا ننتقل إلى تعلّم بالمحاولة والخطأ. نُصيغ الهدف كعملية قرار ماركوفيّة (MDP)، ونُثبت معادلات بيلمان للترقّي والأمثلية، ونبني خوارزميّات (تكرار القيمة/السياسة، Q-learning، تدرّج السياسة، الممثّل–الناقد)، ونحلّل الاستكشاف مقابل الاستغلال وحدود العيّنة والندامة.
سبع نظريات:

- **2.44 MDP ودوالّ القيمة** — $G_t = \sum_k \gamma^k r_{t+k+1}$، $V^\pi(s) = E_\pi[G_t | S_t = s]$.
- **3.44 معادلة أمثلية بيلمان** — $V^\star(s) = \max_a \sum_{s'} P[R + \gamma V^\star(s')]$.
- **4.44 تكرار القيمة والسياسة** — تقارب $V^k \to V^\star$ بمعدّل γ^k.
- **5.44 تعلّم Q (Q-learning)** — $Q \leftarrow Q + \alpha[r + \gamma \max_{a'} Q(s', a') - Q]$.
- **6.44 تدرّج السياسة وREINFORCE** — $\nabla J(\theta) = E[\sum_t \nabla \log \pi_\theta(a_t|s_t)\, G_t]$.
- **7.44 الاستكشاف مقابل الاستغلال والندامة** — ε-greedy/UCB؛ ندمة $O(\sqrt{T \ln T})$.
- **8.44 الممثّل–الناقد (Actor-Critic)** — تدرّج سياسة بمُرجّح تباين منخفض (advantage).

كلّ نظرية تتبع القالب: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
(S, A, P, R, γ)	عملية MDP	الحالات/الأفعال/الانتقال/المكافأة/الخصم
$V^\pi(s)$	قيمة الحالة تحت π	العائد المتوقّع
$Q^\pi(s, a)$	قيمة الفعل	
γ	عامل الخصم	في $[0, 1)$
$\pi(a \mid s)$	السّياسة	توزيع أفعال
G_t	العائد	$\sum \gamma^k r_{t+k+1}$

الاتفاقيات: $P(s' \mid s, a)$، المكافأة $R(s, a)$ (أو $R(s, a, s')$)؛ عائد غير مخصوم يستلزم حلقات مناسبة. كلّ المعادلات في كتل LTR.

صياغة رسمية: عملية قرار ماركوفيّة خماسيّة (S, A, P, R, γ)؛ العائد المُخصم والحالة وقيمة الفعل تحت سياسة π:

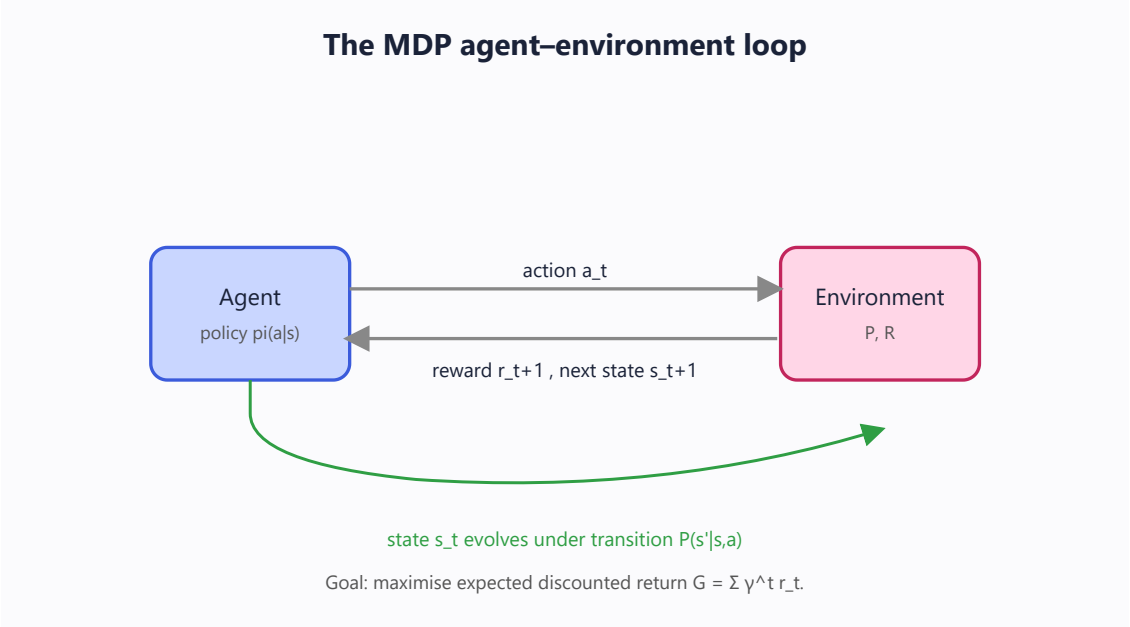
$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}, \qquad V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s], \qquad Q^\pi(s,a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a] \tag{1.44}$$

جدول الرموز

الرمز	المعنى
γ	خصم $[0,1)$ يضمن تقارب العائد
V^π	قيمة البدء من حالة
Q^π	قيمة البدء بفعل من حالة

الرسم

<figure> الشكل<figcaption> 1.44: الوكيل يختار فعلاً، البيئة تُعيد مكافأة وحالة تاليتين؛ الهدف تعظيم العائد



شكل ١٠٤٤: *
حلقة MDP

المُخصم.</figcaption> </figure>

البرهان

الخطوة 1 (تقارب العائد): المكافآت محدودة بـ$R_{\max}$ و$\gamma < 1 \Rightarrow \|G_t\| \le R_{\max}/(1-\gamma)$ منتهٍ. ■

الخطوة 2 (تفكيك ترقوي): $G_t = r_{t+1} + \gamma G_{t+1}$ (خاصيّة ماركوف). ■

الخطوة 3 (معادلة التوقّع): بأخذ التوقّع نحصل على معادلة بيلمان الترقّية لـV^π (تُدمج في 3.44). ■

خمسة عشر مثالاً محلولاً

مثال (1-2.44): مكافأة ثابتة المعطيات: $r = 1$ كلّ خطوة، $\gamma = 0.5$. المطلوب: V^π. الحل: الخطوة 1: $V = 1 + 0.5 \cdot 1 + 0.25 \cdot 1 + \cdots = 1/(1-0.5) = 2$. النتيجة: $V = 2$. الربط بالذكاء الاصطناعي: قيمة دائمة أبداً.

مثال (2-2.44): خصم أعلى المعطيات: نفس (1-2.44)، $\gamma = 0.9$. المطلوب: V. الحل: الخطوة 1: $1/(1-0.9) = 10$. النتيجة: 10. الربط بالذكاء الاصطناعي: γ قريب 1 $\Rightarrow$ قيمة طويلة الأجل.

مثال (3-2.44): $\gamma = 0$ المعطيات: $\gamma = 0$. المطلوب: V. الحل: الخطوة 1: $V = r_{t+1} = 1$ (المستقبل مهمَل). النتيجة: 1. الربط بالذكاء الاصطناعي: جشع لحظيّ.

مثال (4-2.44): MDP صغير مبسّط المعطيات: S_0 (ابتداء) وS_1 (نهائيّ)؛π: من S_0 إلى S_1 بمكافأة 1؛$V(S_1) = 0$؛$\gamma = 0.9$. المطلوب: $V^\pi(S_0)$. الحل: الخطوة 1: $V(S_0) = 1 + 0.9 \cdot V(S_1) = 1 + 0 = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: هدف مباشر.

مثال (5-2.44): سياسة البقاء المعطيات: π تبقى في S_0 بمكافأة 0 (حلقة)؛$\gamma = 0.9$. المطلوب: $V(S_0)$. الحل: الخطوة 1: $V = 0 + 0.9V \Rightarrow V(1-0.9) = 0 \Rightarrow V = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: بقاء بلا مكافأة.

مثال (6-2.44): سياسة مختلطة المعطيات: $\pi(\text{go}) = p, \pi(\text{stay}) = 1-p$؛go؛$S_0, S_1$؛stay مكافأة 1 ثمّ S_1 مكافأة 0. المطلوب: $V(S_0)$ كدالّة في p. الحل: الخطوة 1: $V = p\cdot 1 + (1-p)\cdot 0.9V \Rightarrow V(1-0.9(1-p)) = p \Rightarrow V = p/(0.1+0.9p)$. النتيجة: $V = p/(0.1+0.9p)$. الربط بالذكاء الاصطناعي: سياسة احتماليّة.

مثال (7-2.44): تقييم مختلط عدديّ المعطيات: $p = 0.5$ (من 6-2.44)، $\gamma = 0.9$. المطلوب: V. الحل: الخطوة 1: $V = 0.5/(0.1+0.45) = 0.5/0.55 = 0.909$. النتيجة: 0.909. الربط بالذكاء الاصطناعي: أقلّ من الذهاب الحتميّ (=1).

مثال (8-2.44): مكافأة متأخّرة المعطيات: $r = 0$ لأول 3 خطوات، ثمّ $r = 1$ عند الخطوة 4؛$\gamma = 0.9$. المطلوب: V المبسّط (احتمال 1). الحل: الخطوة 1: $V = 0.9^3 \times 1 = 0.729$. النتيجة: 0.729. الربط بالذكاء الاصطناعي: التّأجيل يخفض القيمة.

مثال (9-2.44): عائد خطوتين المعطيات: $r_1 = 1, r_2 = 1$ ثمّ ينتهي؛$\gamma = 0.5$. المطلوب: V. الحل: الخطوة 1: $V = 1 + 0.5 \times 1 = 1.5$. النتيجة: 1.5. الربط بالذكاء الاصطناعي: مجموع مُخصم من خطوتين.

مثال (10-2.44): رسم انتقال واحد المعطيات: $P(S_1|S_0,a) = 0.8$ مكافأة 1، وإلاّ S_0 مكافأة 0؛$\gamma = 0.9$. المطلوب: $V(S_0)$ (سياسة a دائماً). الحل: الخطوة 1: $V = 0.8 \times (1 + 0.9V(S_1)) + 0.2 \times (0 + 0.9V)$ مع $V(S_1) = 0$ $\Rightarrow V = 0.8 + 0.18V \Rightarrow 0.82V = 0.8 \Rightarrow V = 0.976$. النتيجة: $0.976 \approx$. الربط بالذكاء الاصطناعي: انتقال عشوائيّ.

مثال (11-2.44): قيمة الفعل Q المعطيات: من (10-2.44)، π يختار a دائماً. المطلوب: $Q^\pi(S_0,a)$. الحل: الخطوة 1: $Q(S_0,a) = \mathbb{E}[r + \gamma V^\pi(s')] = 0.8 \times 1 + 0.2 \times 0 + 0.9(...)$؛ مباشرةً $Q = V(S_0) = 0.976$ (خيارٌ واحد). النتيجة: 0.976. الربط بالذكاء الاصطناعي: $Q = V$ لسياسة حتميّة بفعل واحد.

مثال (12-2.44): فرق Q وV المعطيات: فعلان a, b؛$Q(a) = 1, Q(b) = 0.5$؛$\pi(a) = 0.6, \pi(b) = 0.4$. المطلوب: V^π. الحل: الخطوة 1: $V = 0.6 \times 1 + 0.4 \times 0.5 = 0.6 + 0.2 = 0.8$. النتيجة: 0.8. الربط بالذكاء الاصطناعي: $V = \sum \pi Q$.

مثال (13-2.44): تحديد الأمثل المعطيات: $Q(a) = 1, Q(b) = 0.5$. المطلوب: السياسة الأمثلة. الحل: الخطوة 1: $V^\star = \max(Q(a), Q(b)) = 1$ باختيار a. النتيجة: 1. الربط بالذكاء الاصطناعي: أمثل كحدّ أقصى.

مثال (14-2.44): متوسط على عدد خطوات المعطيات: حلقية بمكافأة 1، $\gamma = 0.99$. المطلوب: V. الحل: الخطوة 1: $1/(1-0.99) = 100$. النتيجة: 100. الربط بالذكاء الاصطناعي: أفق زمنيّ طويل.

مثال (15-2.44): خلاصة المعطيات: $\gamma \in [0,1)$؛R محدودة. المطلوب: ضابط محدوديّة العائد. الحل: الخطوة 1: $\|G\| \le R_{\max}/(1-\gamma)$ يتناسب عكسيّاً مع $1-\gamma$. النتيجة: حدّ محدود. الربط بالذكاء الاصطناعي: شرط تقارب.

أخطاء شائعة

- **نسيان $\gamma < 1$:** بلا خصم قد يكون العائد غير منتهٍ.
- **الخلط بين V وQ:** $V^\pi(s) = \sum_a \pi(a|s) Q^\pi(s,a)$.
- **إهمال خاصيّة ماركوف:** التطوّر يعتمد على الحالة لا التاريخ.
- **الخلط بين المكافأة والعائد:** الأخير مجموع مُخصم.
- **نسيان قاعدة الوسط المتوقّع:** V^π متوسّط على الانتقالات والسياسة.

صياغة رسمية: تُعرَّف القيم الأمثلى وتُبرّر بمعامل انقباض $\gamma < 1$:

$$V^\star(s) = \max_a \sum_{s'} P(s' \mid s,a)\big[R(s,a,s') + \gamma V^\star(s')\big], \qquad V^\star(s) = \max_a Q^\star(s,a) \tag{2.44}$$

$$Q^\star(s,a) = \sum_{s'} P(s' \mid s,a)\big[R(s,a,s') + \gamma \max_{a'} Q^\star(s',a')\big] \tag{3.44}$$

والسياسة المثلى $\pi^\star(s) = \arg\max_a Q^\star(s,a)$.

جدول الرموز

الرمز	المعنى
$V^\star, Q^\star$	القيم الأمثلى
$\mathcal{T}$	معامل بيلمان الأمثليّ
$\pi^\star$	السياسة الأمثلى

الرسم

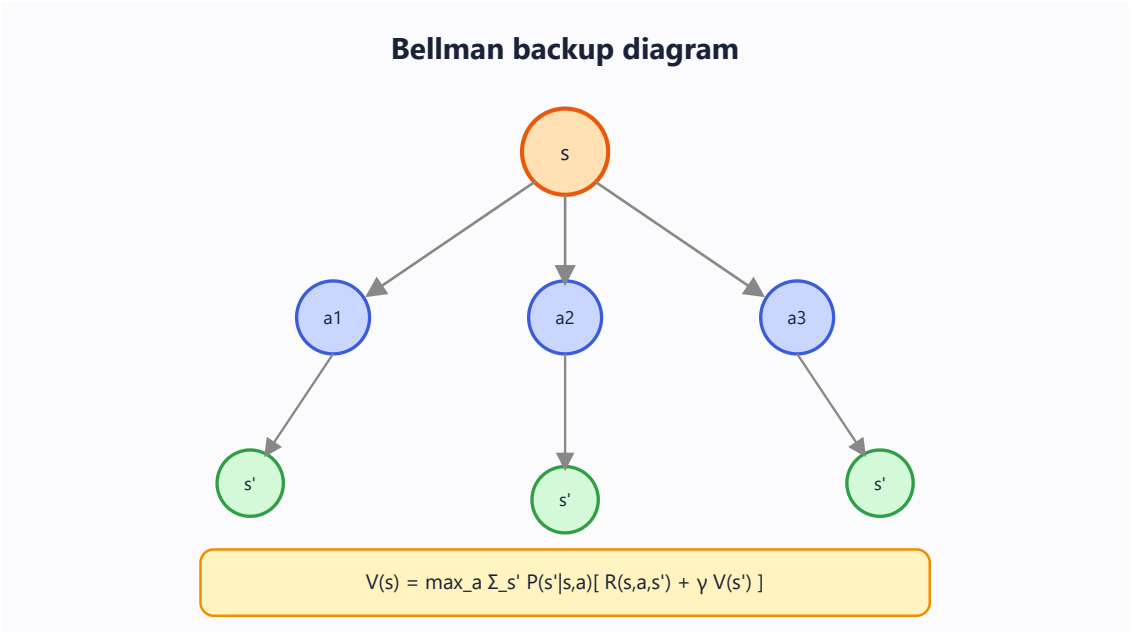
<figure> الشكل<figcaption> 2.44: تُجمَع قيمة كلّ نتيجة محتملة فتُضاف المكافأة والقيمة المخصومة، ثمّ نأخذ الأفضل بين الأفعال.</figcaption></figure>

البرهان

الخطوة 1 (البنية الأمثلى): القيمة المثلى = أفضل قرار حالّاً ثمّ الاستمرار أمثليّاً. ■
الخطوة 2 (الانقباض): $\mathcal{T}$ انقباض (بمعامل γ)؛ $\|\mathcal{T}V - \mathcal{T}U\|_\infty \le \gamma \|V - U\|_\infty \Rightarrow$ نقطة ثابتة وحيدة (بانوفيتش). ■
الخطوة 3 (الاستخلاص): من نقطة $V^\star$ الثابتة نستخرج $Q^\star$ ثمّ $\pi^\star$. ■

خمسة عشر مثالاً محلولاً

مثال (1-3.44): $V^\star$ لـgo/stay المعطيات: من (2.44-4)، $\gamma = 0.9$، $V^\star(S_1) = 0$. المطلوب: $V^\star(S_0)$. الحل: الخطوة 1: $Q^\star(\text{go}) = 1 + 0.9 \cdot 0 = 1$؛ $Q^\star(\text{stay}) = 0 + 0.9 V^\star(S_0)$. الخطوة 2: $V^\star = \max(1, 0.9V^\star) = 1$ (لأنّ $0.9V^\star < 1$). النتيجة: $V^\star(S_0) = 1$. الربط بالذكاء الاصطناعي: الذهاب أمثل.
مثال (2-3.44): $Q^\star(\text{stay})$ المعطيات: من (1-3.44)، $V^\star(S_0) = 1$. المطلوب: $Q^\star(S_0, \text{stay})$. الحل: الخطوة 1: $0 + 0.9 \times 1 = 0.9$. النتيجة: $0.9 < 1$. الربط بالذكاء الاصطناعي: البقاء أسوأ.



شكل ٢٠٤٤: *
نسخة بيلمان الاحتياطيّة

مثال (3-3.44): استخلاص $\pi^\star$ المعطيات: $Q^\star(\text{go}) = 1, Q^\star(\text{stay}) = 0.9$. المطلوب: $\pi^\star$. الحل: الخطوة 1: $\pi^\star(S_0) = \text{go}$ (الأكبر). النتيجة: go. الربط بالذكاء الاصطناعي: سياسة أمثلى.

مثال (4-3.44): حالتا قيمة المعطيات: توزيع ثابتٍ بمكافأة 0.5 في S_0، انتقال حتميّ إلى S_1 مكافأة 2 ثمّ يبقى في S_1؛ $\gamma = 0.9$. المطلوب: $V^\star(S_1)$ ثمّ $V^\star(S_0)$. الحل: الخطوة 1: $V^\star(S_1) = 2/(1-0.9) = 20$. الخطوة 2: $V^\star(S_0) = \max(0.5 + 0.9V^\star(S_0),\ 0.5 + 0.9 \cdot 20) = \max(5,\ 18.5) = 18.5$. النتيجة: $V^\star(S_0) = 18.5$. الربط بالذكاء الاصطناعي: الانتقال الطويل.

مثال (5-3.44): انقباض المعطيات: $\|V_1 - V_2\|_\infty = 2$، $\gamma = 0.9$. المطلوب: $\|\mathcal{T}V_1 - \mathcal{T}V_2\|_\infty$ حدّاً. الحل: الخطوة 1: $1.8 = \gamma \cdot 2 \le$. النتيجة: ≤ 1.8. الربط بالذكاء الاصطناعي: تقليص الفجوة.

مثال (6-3.44): نقطة ثابتة المعطيات: $V^\star = \mathcal{T}V^\star = 0.9$. المطلوب: التأكّد من التطابق. الحل: الخطوة 1: هذا تعريف القيمة الأمثليّة (حلّ النقطة الثابتة). النتيجة: يتحقّق. الربط بالذكاء الاصطناعي: حلّ معادلة ديفونسيّ.

مثال (7-3.44): قيمة نهائيّة أكبر المعطيات: انتقال «go» إلى حالة نهائيّة بمكافأة 100؛ $V(\text{term}) = 0$. المطلوب: $Q^\star(\text{go})$. الحل: الخطوة 1: $100 = 0 + \gamma \cdot 100$. النتيجة: 100. الربط بالذكاء الاصطناعي: هدف بعيد ثمّ استقلال.

مثال (8-3.44): أفضل فعل بفارق صغير المعطيات: $Q(a) = 1.0, Q(b) = 0.99$؛ ε_greedy؛ $\varepsilon = 10^{-3}$. المطلوب: احتمال الاختيار الصحيح. الحل: الخطوة 1: $1 - \varepsilon/2 = 0.9995$ (مع fallback عشوائيّ). النتيجة: 0.9995. الربط بالذكاء الاصطناعي: يقارب الأفضل.

مثال (9-3.44): تفضيل التأجيل مقابل العائد المعطيات: a يعطي 1 حالاً، b يعطي 2 بعد ثلاث خطوات؛ $\gamma = 0.5$. المطلوب: أيّهما أمثل من $V^\star$؟ الحل: الخطوة 1: $V(a) = 1$؛ $V(b) = 2 \cdot 0.5^3 = 0.25$؛ الأفضل a. النتيجة: a. الربط بالذكاء الاصطناعي: خصم يُرجّح العاجل.

مثال (10-3.44): المعطيات: نفس (9-3.44)، $\gamma = 0.99$. المطلوب: أيّهما؟ الحل: الخطوة 1: $2 \times 1 < 2 \cdot 0.99^3 = 1.941 \Rightarrow$ يجيء b. النتيجة: b. الربط بالذكاء الاصطناعي: صبر مطلوب.

مثال (11-3.44): حالة عشوائية متماثلة المعطيات: من S انتقال 0.5 إلى قيمة 10، 0.5 إلى 0؛ $\gamma = 0.9$. المطلوب: $V^\star$. الحل: الخطوة 1: $V = 5$ (إنهاء)؛ أو $0.5 \times 10 + 0.5 \times 0 = 5$؛ $0.5(10) + 0.5(0.9V)$، بحالة إنهاء $V = 5$.

النتيجة: 5. الربط بالذكاء الاصطناعي: متوسط عشوائيّ.

مثال (12-3.44): حلّ نظام خطّي المعطيات: $V = s_0 + \gamma(pV_a + (1-p)V_b)$؛ $V_a = 5, V_b = 0, p = 0.5, \gamma = 0.9, s_0 = 1$. المطلوب: V. الحل: الخطوة 1: $V = 1 + 0.9(0.5 \times 5 + 0.5 \times 0) = 1 + 0.9 \times 2.5 = 3.25$. النتيجة: 3.25. الربط بالذكاء الاصطناعي: انتظام وحلّ.

مثال (13-3.44): مكافأة سالبة المعطيات: كلّ خطوة -1 حتّى الهدف؛ وصول بعد 5 خطوات؛ $\gamma = 0.9$. المطلوب: V المبدئيّة. الحل: الخطوة 1: $-4.095 = -(1 + 0.9 + 0.81 + 0.729 + 0.656)$. النتيجة: -4.095. الربط بالذكاء الاصطناعي: كلفة المسار.

مثال (14-3.44): مسار أقصر أفضل المعطيات: كلفة خطوة -0.5؛ وصول بعد خطوتين مقابل أربع. المطلوب: V (أقرب أفضل). الحل: الخطوة 1: خطوتان: -1.0؛ أربع: $-2.0 \Rightarrow$ الأقرب أفضل قيمة أعلى (-1.0). النتيجة: المختار الأقصر. الربط بالذكاء الاصطناعي: تحسين المسار.

مثال (15-3.44): خلاصة المعطيات: $\pi^\star = \arg\max_a Q^\star$. المطلوب: توقّع $V^{\pi^\star}$. الحل: الخطوة 1: $V^{\pi^\star} = V^\star$ (الأسمى). النتيجة: $V^\star$. الربط بالذكاء الاصطناعي: بلوغ الأمثل.

أخطاء شائعة

- **الخلط بين** max **في** $V^\star$ **والأفعال الممكنة فقط:** يجب أخذ الحدّ الأقصى على كامل A (حتى غير القابلة للوصول).
- **نسيان** γ **في التوقّع المخصوم:** المكافأة القادمة تخصم مرّة واحدة فقط لكلّ خطوة.
- **الظنّ أن** $V^\star \neq \max Q^\star$: بل متطابقان.
- **إهمال خاصيّة ما بعد:** مكافأة الحالة التالية تلزم $\gamma V^\star(s')$ بعد الخطوة.
- **نسيان انقباض بانوفيتش:** يضمن وحدانيّة الحلّ.

صياغة رسمية: تكرار القيمة يطبّق معامل بيلمان الأمثليّ $V_{k+1}(s) = \mathcal{T}V_k(s) = TV_k(s)$؛ وتحسين السياسة تزايديّ:

$$\text{تحسين: } \pi'(s) = \arg\max_a Q^\pi(s,a) \qquad \text{تقييم: } (I - \gamma P^\pi)V^\pi = r^\pi, \tag{4.44}$$

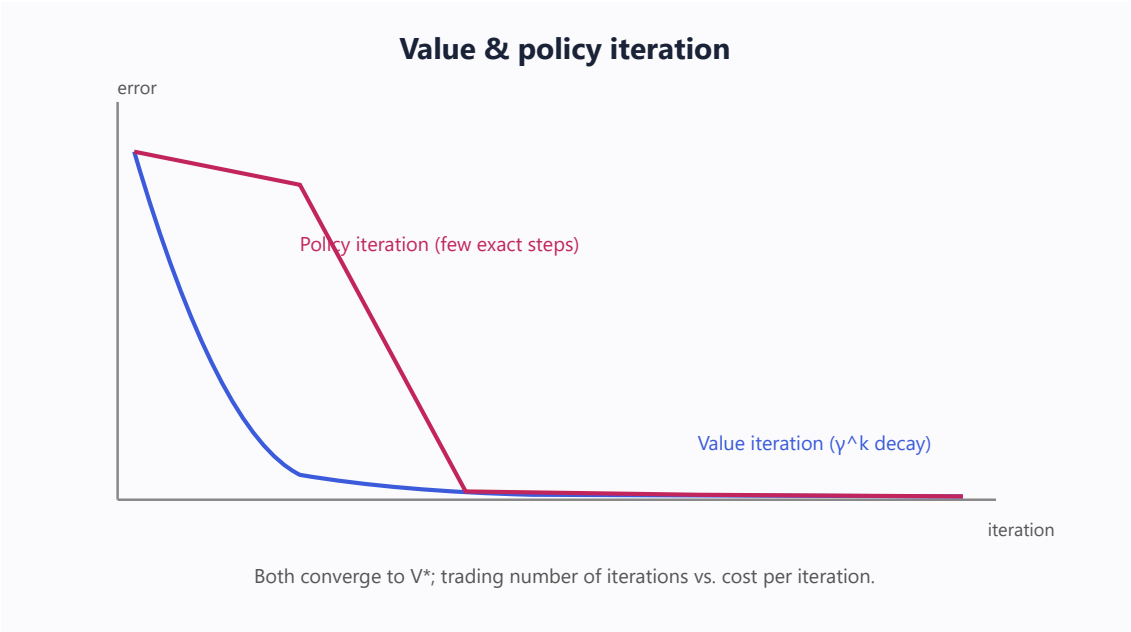
تكرار القيمة يتقارب هندسيّاً؛ وتحسين السياسة تزايديّ ينتهي نهائيّاً.

جدول الرموز

الرمز	المعنى
$\mathcal{T}$	معامل بيلمان الأمثليّ
P^π, r^π	مصفوفة الانتقال والمكافأة تحت π
γ^k	معدّل تقارب تكرار القيمة

الرسم

<figure> الشكل<figcaption> 3.44: قيمة التكرار تتقارب هندسيّاً (γ^k)؛ تكرار السياسة يبلغ الأمثل في خطوات معدودة دقيقة.</figcaption> </figure>



شكل ٤٤.٣: *
تكرار القيمة/السياسة

البرهان

الخطوة 1 (تقارب VI): $\|V_k - V^\star\|_\infty \le \gamma^k \|V_0 - V^\star\|_\infty \Rightarrow$ تقارب هندسيّ. ■

الخطوة 2 (تقييم دالّة السياسة): $V^\pi = (I - \gamma P^\pi)^{-1} r^\pi$ (القسمة ممكنة لأنّ $I - \gamma P^\pi$ قابلة للعكس بمعيّاريّ $(1/(1-\gamma))$. ■

الخطوة 3 (تحسين تزايديّ): $V^{\pi'} \ge V^\pi$ بدليل $Q^\pi(s, \arg\max) \ge V^\pi(s)$؛ وعدد السياسات الحتميّة منتهٍ $\Rightarrow$ توقّف. ■

خمسة عشر مثالاً محلولاً

مثال (4.44-1): تكرار القيمة المُبسّط المعطيات: $V^\star(S_0) = 1$ (من 4.44-3)، $\gamma = 0.9$، $V_0 = 0$، $V_k = 1 - 0.9^k$. المطلوب: V_5. الحل: الخطوة 1: $V_5 = 1 - 0.9^5 = 1 - 0.59049 = 0.4095$. النتيجة: 0.4095. الربط بالذكاء الاصطناعي: تقارب تدريجيّ.

مثال (4.44-2): عدد خطوات لخطأ المعطيات: 0.01 حيث $\gamma = 0.9$. المطلوب: k حيث $0.9^k < 0.01$. الحل: الخطوة 1: $k > \ln(0.01)/\ln(0.9) = (-4.605)/(-0.105) = 43.7 \Rightarrow k = 44$. النتيجة: $k \approx 44$. الربط بالذكاء الاصطناعي: γ بعيد من 1 يحتاج خطواتاً أكثر.

مثال (4.44-3): المعطيات: نفس الشرط 0.01 $\gamma = 0.5$. المطلوب: k. الحل: الخطوة 1: $0.5^k < 0.01 \Rightarrow k > \ln 0.01/\ln 0.5 = (-4.605)/(-0.693) = 6.6 \Rightarrow 7$. النتيجة: 7. الربط بالذكاء الاصطناعي: تقارب أسرع بخصم أقلّ.

مثال (4.44-4): حدّ الخطأ المبكّر المعطيات: $V^\star = 20$ (من 4.44-3)، $\gamma = 0.9$، $\|V_0 - V^\star\|_\infty = 20$؛ حتى الخطأ < 0.5. المطلوب: k. الحل: الخطوة 1: $20 \cdot 0.9^k < 0.5 \Rightarrow 0.9^k < 0.025 \Rightarrow k > \ln 0.025/\ln 0.9 = 34.9 \Rightarrow 35$. النتيجة: $k = 35$. الربط بالذكاء الاصطناعي: يأخذ المقياس وقتاً.

مثال (4.44-5): تقييم دالّة السياسة المعطيات: π يبقى في S بمكافأة 0؛ $\gamma = 0.5$. المطلوب: $V^\pi(S)$ عبر نظام خطّي. الحل: الخطوة 1: $V = (1-\gamma)V + 0 \Rightarrow V(1 - 0.5) = 0 \Rightarrow V = 0$. النتيجة: 0. الربط بالذكاء

الاصطناعي: حلّ نظام.

مثال (6-4.44): عكس $(I-\gamma P^\pi)$ المعطيات: حالة واحدة، $\gamma=0.9$، $P^\pi=1$، $r=1$. المطلوب: V^π. الحل: الخطوة 1: $V=1/(1-0.9)=10$. النتيجة: 10. الربط بالذكاء الاصطناعي: مكافأة دائمة.

مثال (7-4.44): تحسين تزايديّ المعطيات: $V^\pi=2$؛ سياسة جديدة π' تحقّق 3. المطلوب: هل التحسين يتقبّل π'؟ الحل: الخطوة 1: مباشرةً لقبول π' لأنّها أعلى قيمة (تحسين تزايديّ). النتيجة: نعم. الربط بالذكاء الاصطناعي: تقدّم تزايديّ.

مثال (8-4.44): الوصول للسياسة الأمثلى المعطيات: سياسة قابلة للتحسين لا نهائيّاً. المطلوب: توقّف. الحل: الخطوة 1: كلّ تحسين يضمن التحسن حتى يتوقّف عند $\pi^\star$ (منتهٍ: عدد السياسات محدود). النتيجة: توقّف عند $\pi^\star$. الربط بالذكاء الاصطناعي: تكرار السياسة يبلغ النهاية.

مثال (9-4.44): عدد السياسات المعطيات: n حالة، $2=\|A\|$، P قابلة للحساب. المطلوب: عدد السياسات الحتميّة. الحل: الخطوة 1: 2^n نظريّاً، لكن تكرار السياسة لا يمرّها كلّها؛ لأنّ التحسين يرفع القيمة بلا نقصان فينتهي عند الأفضل. النتيجة: منتهٍ عمليّاً. الربط بالذكاء الاصطناعي: تكرار منتهٍ.

مثال (10-4.44): مقارنة عدد الخطوات المعطيات: نفسُ الهدف. المطلوب: VI مقابل PI. الحل: الخطوة 1: VI $\sim O(\ln(1/\varepsilon)/\ln(1/\gamma))$؛ PI عادةً 5-20 خطوة دقيقة. النتيجة: PI أسرع في الخطوات لكن أغلى خطوةً. الربط بالذكاء الاصطناعي: مفاضلة زمن/حساب.

مثال (11-4.44): خطأ بعد k المعطيات: $\Delta_k=\|V_k-V_{k-1}\|_\infty=0.2$، $\gamma=0.5$. المطلوب: حدّ نهائيّ للخطأ المتبقّي. الحل: الخطوة 1: $\|V_k-V^\star\|_\infty\le\frac{\gamma}{1-\gamma}\Delta_k=\frac{0.5}{0.5}\times0.2=0.2$. النتيجة: ≤0.2. الربط بالذكاء الاصطناعي: معيار توقّف.

مثال (12-4.44): عند $\gamma=0.9$ المعطيات: نفس $\Delta_k=0.2$، $\gamma=0.9$. المطلوب: الحدّ. الحل: الخطوة 1: $\frac{0.9}{0.1}\times0.2=9\times0.2=1.8$. النتيجة: ≤1.8. الربط بالذكاء الاصطناعي: لا يعطي تأكيداً دقيقاً.

مثال (13-4.44): تقييم بالحلّ المباشر المعطيات: P^π قابلة للعكس. المطلوب: كيف نحلّ التقييم؟ الحل: الخطوة 1: $V=(I-\gamma P^\pi)^{-1}r$ بحلّ خطّي مباشر. النتيجة: حلّ مباشر. الربط بالذكاء الاصطناعي: حساب دقيق.

مثال (14-4.44): تقريب تقييم المعطيات: بدل حلّ دقيق نطبّق $V\leftarrow r+\gamma P^\pi V$ تكراراً. المطلوب: اسم الطريقة. الحل: الخطوة 1: تقييم تكرار تقريبيّ (يتطلّب خطوات $\ln(1/\varepsilon)/\ln(1/\gamma)$). النتيجة: تقريب متكرّر. الربط بالذكاء الاصطناعي: تكلفة أقلّ.

مثال (15-4.44): خلاصة المعطيات: $\gamma=0.95$، $\varepsilon=0.01$. المطلوب: عدد خطوات VI المطلوب تقريباً. الحل: الخطوة 1: $k\approx\ln(0.01)/\ln(0.95)=(-4.605)/(-0.0513)=90$. النتيجة: $k\approx90$. الربط بالذكاء الاصطناعي: γ قريب $1\Rightarrow$ بطيء.

أخطاء شائعة

- **الخلط بين γ^k ومعدّل سريع:** γ قريب 1 يبطّئ التقارب كثيراً.
- **نسيان عكس $(I-\gamma P^\pi)$:** تقييم السياسة حلّ خطّيّ لا تكرار حتميّ.
- **الظنّ أن التحسين يتطلّب $V^\star$:** يكفي V^π مع $\arg\max_a Q^\pi$.
- **الخلط بين عدد خطوات VI وPI:** كارئ-هوما متنوّعة من حيث الكلفة لكلّ خطوة.
- **إهمال معيار التوقّف:** Δ_k يقدّر الخطأ بمقدار $\frac{\gamma}{1-\gamma}$.

صياغة رسمية: قاعدة تعلّم Q بلا نموذج (model-free)، خارج-السياسة:

$$Q(s,a) \leftarrow Q(s,a) + \alpha\Big[r + \gamma \max_{a'} Q(s',a') - Q(s,a)\Big] \tag{5.44}$$

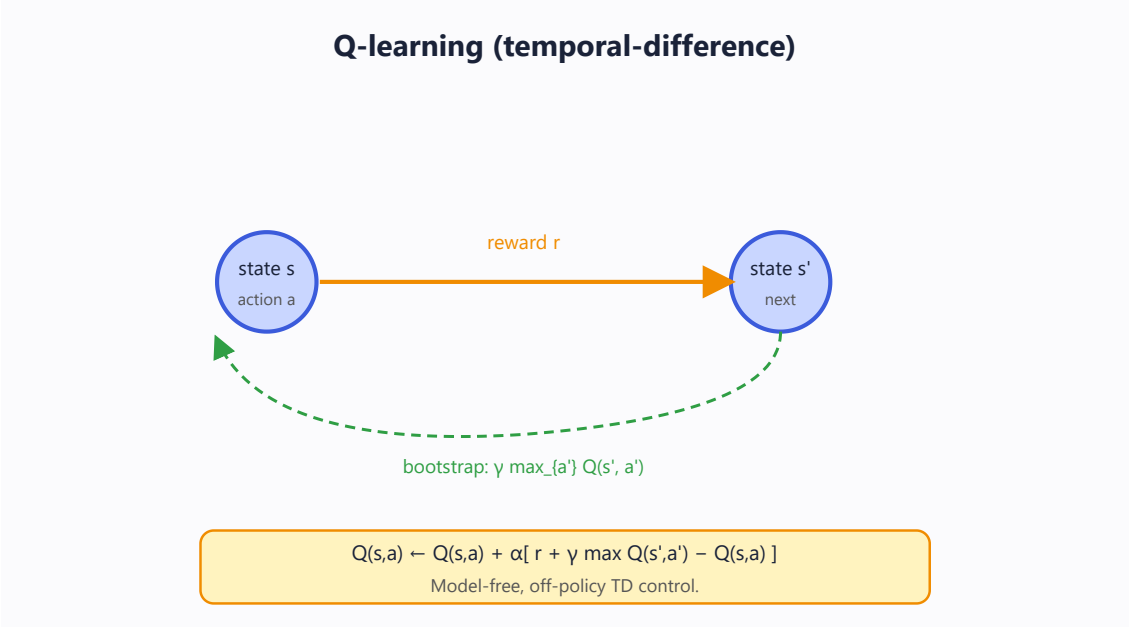
حيث الهدف ينتظم باستعارة bootstrap من أفضل فعل تالٍ؛ يتقارب $Q \to Q^\star$ جدولياً.

جدول الرموز

الرمز	المعنى
α	معدّل التعلّم
خارج-السياسة	السياسة السّلوكيّة تختلف عن الهدف
on-policy	SARSA (الهدف يتبع π)

الرسم

<figure> الشكل<figcaption> 4.44: تحديث الزوج الحاليّ بمكافأة فوريّة واستعارة من أفضل فعل



شكل ٤٤.٤٤: *
Q-learning

تالٍ.</figcaption> </figure>

البرهان

الخطوة 1 (هدف الفرق الزمنيّ): الهدف $r + \gamma \max_{a'} Q(s',a')$ عيّنة من الحدّ الأيمن لمعامل بيلمان الأمثليّ. ■

الخطوة 2 (التوقّع): المتوقّع من التحديث هو $\mathbb{E}[Q_{new} \mid s,a] = Q(s,a) + \alpha(\mathcal{T}Q(s,a) - Q(s,a)) \Rightarrow$ ينزاح نحو نقطة $\mathcal{T}Q$. ■

الخطوة 3 (التقارب): $\mathcal{T}Q$ انقباض (بمعامل γ)؛ مع زيارات لا نهائيّة وα متناقص (روبينز-مونرو) يتقارب $Q \to Q^\star$ احتمالاً 1. ■

خمسة عشر مثالاً محلولاً

مثال (1-5.44): تحديث أول المعطيات: $Q(s,a)=0.5$، $r=1$، $\gamma=0.9$، $\max_{a'} Q(s',a')=2$، $\alpha=0.1$. المطلوب: Q_{new}. الحل: الخطوة 1: الهدف $1+0.9\times 2=2.8$. الخطوة 2: $Q=0.5+0.1(2.8-0.5)=0.73$. النتيجة: $0.5+0.23=0.73$. الربط بالذكاء الاصطناعي: تحديث بـTD.

مثال (2-5.44): تعلّم أسرع المعطيات: نفس (1-5.44) لكن $\alpha=0.5$. المطلوب: Q_{new}. الحل: الخطوة 1: $0.5+0.5(2.3)=0.5+1.15=1.65$. النتيجة: 1.65. الربط بالذكاء الاصطناعي: α كبير يسرّع.

مثال (3-5.44): هدف سالب المعطيات: $r=-1$، $Q=0$، $\max_{a'}=0$، $\alpha=0.1$، $\gamma=0.9$. المطلوب: Q_{new}. الحل: الخطوة 1: الهدف $-1+0=-1$؛ $Q=0+0.1(-1-0)=-0.1$. النتيجة: -0.1. الربط بالذكاء الاصطناعي: عقوبة تُنقل للقيمة.

مثال (4-5.44): الوصول للهدف المعطيات: $Q=2.8$ (أو قريب)، الهدف ثابت 2.8. المطلوب: التحديث. الحل: الخطوة 1: الفرق صفر $\Rightarrow$ لا تغيير. النتيجة: ثابت (نقطة ثابتة). الربط بالذكاء الاصطناعي: التقارب عند الهدف.

مثال (5-5.44): حد أفضل تالٍ المعطيات: $\max(0.5,1.0,0.3)=\max_{a'} Q(s',a')$. المطلوب: القيمة. الحل: الخطوة 1: 1.0. النتيجة: 1.0. الربط بالذكاء الاصطناعي: bootstrapping أمثليّ.

مثال (6-5.44): SARSA مقابل Q المعطيات: الفعل التالي الفعليّ a_π بـ$Q(s',a_\pi)=0.4$؛ $\max=1.0$، $r=0$، $\gamma=0.9$. المطلوب: الفرق بين هدف SARSA وQ. الحل: الخطوة 1: SARSA هدف $0+0.9\times 0.4=0.36$؛ Q هدف $0+0.9\times 1.0=0.9$. النتيجة: SARSA 0.36 مقابل Q 0.9. الربط بالذكاء الاصطناعي: على-السياسة مقابل خارجها.

مثال (7-5.44): greedy-ε المعطيات: $\varepsilon=0.1$، 4 أفعال. المطلوب: احتمال اختيار الأفضل. الحل: الخطوة 1: $1-0.1+0.1/4=0.925$ (أفضل حتمياً مع مصادفة). النتيجة: 0.925. الربط بالذكاء الاصطناعي: توازن استكشاف.

مثال (8-5.44): استقرار مع α ثابت المعطيات: $\alpha=1$. المطلوب: التحديث. الحل: الخطوة 1: $Q\leftarrow$ الهدف مباشرةً (استبدال تامّ). النتيجة: تذبذب محتمل. الربط بالذكاء الاصطناعي: α كبير غير مستقرّ.

مثال (9-5.44): تناقص α المعطيات: $\alpha_t=1/t$ (روبينز-مونرو). المطلوب: لماذا؟ الحل: الخطوة 1: يجمع توقّعات متعدّدة بثبات مع تقارب. النتيجة: يقين نقاط. الربط بالذكاء الاصطناعي: شرط التقارب.

مثال (10-5.44): جدول كبير المعطيات: $\|S\|\times\|A\|=10^6$. المطلوب: مشكلة Q جدوليّ. الحل: الخطوة 1: لا يكفي الجدول لأنّ العيّنات لا تكفي لتغطية الكلّ. النتيجة: تعميم مطلوب. الربط بالذكاء الاصطناعي: دافع لـQ بالدالّة.

مثال (11-5.44): DQN المعطيات: نقرّب $Q(s,a;\theta)$ بشبكة. المطلوب: من أين التحسين؟ الحل: الخطوة 1: buffer replay + شبكة هدف $\Rightarrow$ كسر الارتباط الزمنيّ. النتيجة: تعلّم Q بشبكة. الربط بالذكاء الاصطناعي: تعلّم Q عميق (DQN).

مثال (12-5.44): دالة الخسارة المعطيات: $\mathcal{L}=(r+\gamma\max_{a'} Q_{\text{target}}-Q_\theta)^2$. المطلوب: الشكل. الحل: الخطوة 1: مربّع خطأ بيلمان (MSE). النتيجة: MSE. الربط بالذكاء الاصطناعي: هدف تراجعات.

مثال (13-5.44): تحديث متعدّد المعطيات: عيّنان $(r=1,y=2.8)$ و$(r=0.5,y=2.0)$ لـ$Q(s,a)=0.5$، $\alpha=0.1$. المطلوب: التحديث المتتابع. الحل: الخطوة 1: بعد الأوّل 0.73؛ الهدف الثاني $\ldots\times 0.9+0.5=$ نأخذ $y=2\Rightarrow 0.73+0.1(2-0.73)=0.73+0.127=0.857$. النتيجة: 0.857. الربط بالذكاء الاصطناعي: تجميع العيّنات.

مثال (14-5.44): قيم أوّليّة متفائلة المعطيات: $Q_0=5$ (أعلى من الأهداف). المطلوب: أثر الاستكشاف. الحل: الخطوة 1: الأزواج غير المجرّبة تظهر جذّابة $\Rightarrow$ استكشاف مضمن. النتيجة: استكشاف فعّال. الربط بالذكاء الاصطناعي: تهيئة متفائلة.

مثال (15-5.44): خلاصة المعطيات: α ملائم وزيارات لا نهائيّة. المطلوب: ما يتقارب؟ الحل: الخطوة 1: $Q\rightarrow$

$Q^\star$، واستخلاص $\pi = \arg\max_a Q$. النتيجة: $Q^\star$. الربط بالذكاء الاصطناعي: سلوك أمثليّ.

أخطاء شائعة

- **الخلط بين max (Q) والفعل التالي الفعليّ (SARSA):** Q خارج-السياسة، SARSA عليها.
- **نسيان α مناسباً:** ثابت كبير يسبب تذبذباً.
- **إهمال شرط الزيارات:** الجدول يتقارب فقط لو تُزورتس الأزواج لا نهائيّاً.
- **الخلط بين الهدف والقيمة الحاليّة:** التحديث يزحف نحو الفرق لا نحو المكافأة.
- **نسيان أن Q-learning يعتمد bootstrap:** يمكن أن ينحاز إذا كانت Q الابتدائيّة سيّئة.

صياغة رسمية: نزداد احتمال الأفعال المثمرة باستعمال حيلة نسبة الإمكان:

$$\nabla_\theta J(\theta) = \mathbb{E}_\pi\Big[\sum_t \nabla_\theta \log \pi_\theta(a_t|s_t)\, G_t\Big] = \mathbb{E}_\pi\Big[\sum_t \nabla_\theta \log \pi_\theta(a_t|s_t)\,\big(G_t - b(s_t)\big)\Big] \tag{6.44}$$

حيث $b(s_t)$ خطّ أساس (baseline) يخفض التباين بلا تحيّز.

جدول الرموز

الرمز	المعنى
$\nabla \log \pi$	تدرّج لوغاريتم السياسة
$b(s)$	خطّ أساس (غالباً $V(s)$)
G_t	العائد من الخطوة t

الرسم

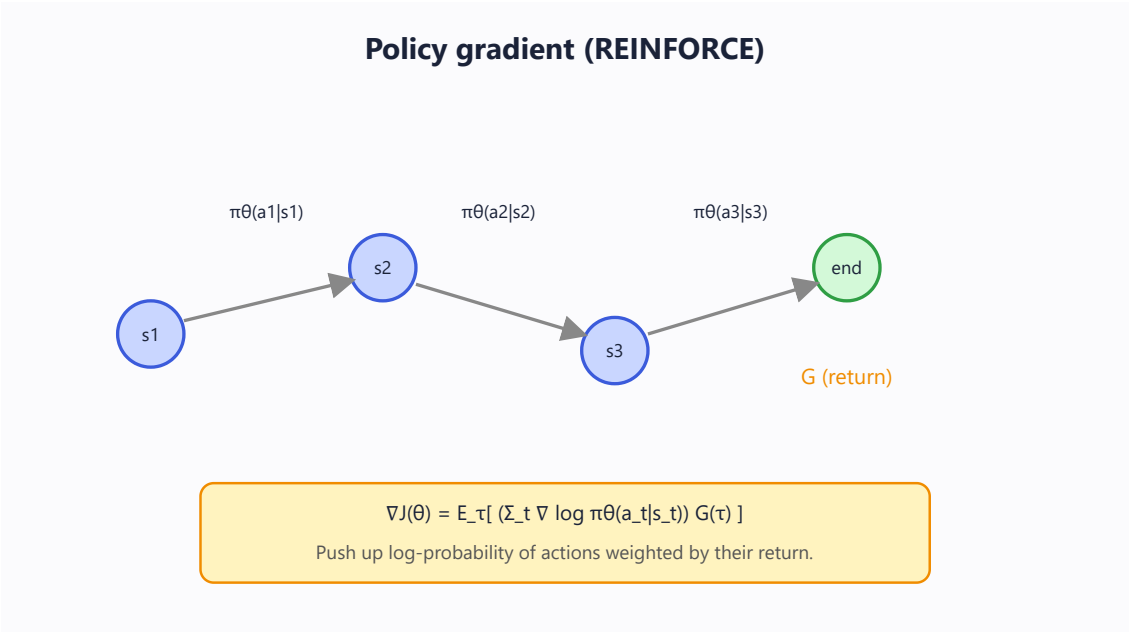
<figure> الشكل<figcaption> 5.44: مسار بأفعال، نرفع لوغاريتم احتمال الأفعال المرتفعة العائد ونخفض غيرها.</figcaption> </figure>

البرهان

الخطوة 1 (حيلة النسبة): $\nabla_\theta \pi_\theta = \pi_\theta \nabla_\theta \log \pi_\theta$، فالتدرّج المتوقّع يصبح توقّعاً على المسارات. ■
الخطوة 2 (حيلة المسار): $\nabla_\theta E_\tau[G(\tau)] = E_\tau[G(\tau)\nabla_\theta \log p(\tau)]$، و$\log p(\tau) = \sum_t \log \pi_\theta(a_t|s_t)$. ■
الخطوة 3 (تخفيض التباين): لأيّ b يعتمد على s فقط: $E_\tau[\nabla \log p \cdot b(\tau)] = 0$ (لأنّ $\sum_a \pi(a)\nabla \log \pi(a|s) = 0$) $\Rightarrow$ لا تحيّز. ■

خمسة عشر مثالاً محلولاً

مثال (6.44-1): توقّع العائد المعطيات: $\pi(a_1) = 0.6, \pi(a_2) = 0.4$؛ $G(a_1) = 10, G(a_2) = 2$. المطلوب: $J = E_\pi[G]$ وخطّ الأساس. الحل: الخطوة 1: $J = 0.6 \times 10 + 0.4 \times 2 = 6 + 0.8 = 6.8$؛ نأخذ $b = 6.8$. النتيجة: $J = 6.8$، $b = 6.8$. الربط بالذكاء الاصطناعي: أساس القيمة.
مثال (6.44-2): مزايا (advantage) المعطيات: من (6.44-1). المطلوب: $A(a_1), A(a_2)$. الحل: الخطوة 1: $A(a_1) = 10 - 6.8 = 3.2$؛ $A(a_2) = 2 - 6.8 = -4.8$. النتيجة: $A = (3.2, -4.8)$. الربط بالذكاء الاصطناعي: a_1 أعلى من المتوسّط.



شكل ٤٤.٥: *
تدرّج السياسة

مثال (3-6.44): تدرّج softmax المعطيات: $\pi = (0.6, 0.4)$، $A = (3.2, -4.8)$. المطلوب: $\nabla_\theta J$ (بوسيطتين θ_1, θ_2). الحل: الخطوة 1: $\nabla \log \pi(a_1) = e_1 - \pi = (0.4, -0.4)$؛ $\nabla \log \pi(a_2) = (-0.6, 0.6)$. الخطوة 2: $\nabla J = 0.6 \times 3.2 \times (0.4, -0.4) + 0.4 \times (-4.8) \times (-0.6, 0.6) = 1.92(0.4, -0.4) + (-1.92)(-0.6, 0.6) = (0.768 + 1.152, -0.768 - 1.152) = (1.92, -1.92)$. النتيجة: $(1.92, -1.92)$. الربط بالذكاء الاصطناعي: يرفع لوغاريتم a_1.

مثال (4-6.44): بلا أساس (اتّجاه) المعطيات: $G(a_1) = 10, G(a_2) = 2$ بلا b. المطلوب: التدرّج. الحل: الخطوة 1: $0.6 \times 10(0.4, -0.4) + 0.4 \times 2(-0.6, 0.6) = 2.4(0.4, -0.4) + 0.8(-0.6, 0.6) = (0.48, -0.48)$. النتيجة: نفس الاتجاه $(0.48, -0.48)$ بعد معامل. الربط بالذكاء الاصطناعي: الأساس لا يغيّر الاتجاه في softmax لكن يقلّل التباين.

مثال (5-6.44): خطوة تحديث المعطيات: $\nabla J = (1.92, -1.92)$، $\alpha = 0.01$. المطلوب: $\Delta\theta$. الحل: الخطوة 1: $(0.0192, -0.0192)$ يرفع θ_1 ويخفض θ_2. النتيجة: $(+0.0192, -0.0192)$. الربط بالذكاء الاصطناعي: صعودًا نحو الأعلى.

مثال (6-6.44): تباين قبل وبعد الأساس المعطيات: عوائد $G = (10, 2)$، تباين-b مقابل تباين-A. المطلوب: التباين-A فرق المتوسّط. الحل: الخطوة 1: تباين G حول الأساس $b = 6.8$: $0.6(10 - 6.8)^2 + 0.4(2 - 6.8)^2 = 0.6(10.24) + 0.4(23.04) = 15.36$ (وهو تباين A لأنّ $A = G - b$). النتيجة: التباين نفسه في هذا التقدير (المكسب واضح بتوزيعات أخرى). الربط بالذكاء الاصطناعي: الأساس يخفض التباين عموماً لا هنا.

مثال (7-6.44): عائد مُخصّم المعطيات: $r = (1, 1, 10)$، $\gamma = 0.5$. المطلوب: G_0. الحل: الخطوة 1: $1 + 0.5 \times 1 + 0.25 \times 10 = 1 + 0.5 + 2.5 = 4$. النتيجة: 4. الربط بالذكاء الاصطناعي: مكافأة نهائيّة تكلّف مُخصَّمة.

مثال (8-6.44): توزيع متوقّع المعطيات: مسار بمكافأة إجماليّة 5. المطلوب: شكل التحديث. الحل: الخطوة 1: $\theta \leftarrow \theta + \alpha \times 5 \times \sum \nabla \log \pi$ (لو $5 > b$). النتيجة: رفع الاحتمالات. الربط بالذكاء الاصطناعي: مكافأة عالية $\Rightarrow$ تعزيز.

مثال (9-6.44): قياس التدرّج المعطيات: $\nabla \log \pi$ نمطه 3.0؛ فعلٌ مكافأته أعلى من الأساس بـ4. المطلوب: مركّب تحديث تقريبيّ. الحل: الخطوة 1: $\alpha \times 4 \times 0.3 = 0.012\alpha$؛ بـ$\alpha = 0.1 \Rightarrow 0.0012$. النتيجة: 0.0012. الربط

بالذكاء الاصطناعي: خطوة صغيرة مستقرّة.

مثال (6.44-10): سياسة على-النهاية المعطيات: عيّنات من π_θ نفسها. المطلوب: هل التدرّج غير متحيّز؟ الحل: الخطوة 1: نعم؛ REINFORCE غير متحيّز (لكن عالي التباين). النتيجة: غير متحيّز. الربط بالذكاء الاصطناعي: على-السياسة.

مثال (6.44-11): العيّنة المهمّة المعطيات: توزيع سلوكيّ $q \neq \pi_\theta$. المطلوب: كيف نصحّح؟ الحل: الخطوة 1: نضرب نسبة importance π_θ/q). (sampling النتيجة: يصبح خارج-السياسة. الربط بالذكاء الاصطناعي: إعادة استخدام عيّنات.

مثال (6.44-12): خط أساس ثابت المعطيات: $b = 0$. المطلوب: هل لا تحيّز؟ الحل: الخطوة 1: نعم؛ كلّ b ثابت يلغي تحيّزاً. النتيجة: صحيح. الربط بالذكاء الاصطناعي: أبسط أساس.

مثال (6.44-13): تيارات سياسة المعطيات: تحديث بخطوة مصغّرة. المطلوب: التأثير نظريّاً. الحل: الخطوة 1: θ يتحرّك نحو أفضل سياسة تدريجيّاً (غالباً غير محدّب). النتيجة: تحسّن تدرّجيّ. الربط بالذكاء الاصطناعي: صعوداً غير محدّب.

مثال (6.44-14): استقرار المعطيات: $\alpha = 0.1$ (كبير). المطلوب: الخطر. الحل: الخطوة 1: تذبذب في السياسة؛ يفضّل α صغير. النتيجة: ثبات أفضل ب α أصغر. الربط بالذكاء الاصطناعي: ضبط معدّل.

مثال (6.44-15): خلاصة المعطيات: $\pi(a_1) = 0.5, A = +2$. المطلوب: اتجاه التحديث لـa_1. الحل: الخطوة 1: نرفع لوغاريتم احتمال a_1 (أعلى من الأساس). النتيجة: زيادة احتمال a_1. الربط بالذكاء الاصطناعي: تعزيز الفعل الجيّد.

أخطاء شائعة

- **نسيان حيلة النسبة:** $\nabla\pi = \pi\nabla\log\pi$ أساس البرهان.
- **ظنّ أنّ الأساس يُحوّل الاتجاه:** في softmax لا يغيّره (لأنّ $E[\nabla\log\pi] = 0$) لكنه يخفض التباين.
- **الخلط بين العائد والمكافأة:** الصيغة تستعمل G_t المُخمَّن لا r_t.
- **استخدام أساس يعتمد على الفعل:** يُدخِل تحيّزاً.
- **إهمال طبيعة على-السياسة:** حيلة العيّنة المهمّة لإعادة الاستخدام.

صياغة رسمية: عند عدم التأكّد من قيم الأفعال، نوازن بين تجربة أفعال جديدة واستعمال الأفضل:

$$\text{UCB:} a_t = \arg\max_a \left(\hat{\mu}_a + c\sqrt{\tfrac{\ln t}{N_a}}\right), \qquad R(T) = \sum_{t=1}^{T}\left(\mu^\star - \mu_{a_t}\right) \tag{7.44}$$

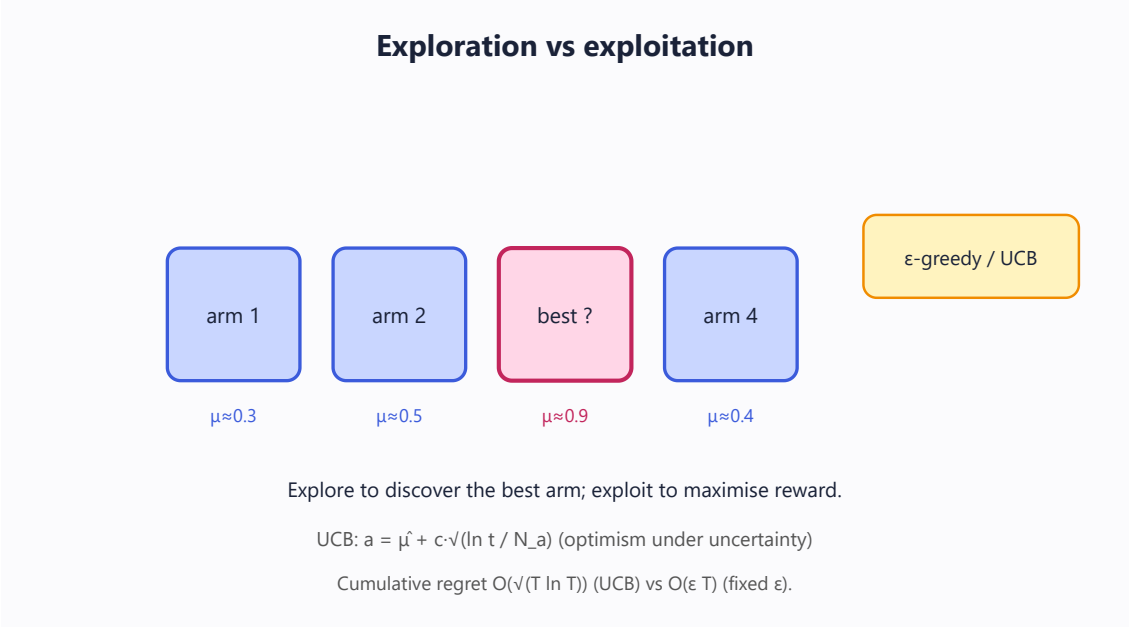
ندامة ε-greedy الخطيّة $O(\varepsilon T + \frac{K}{\varepsilon})$؛ وندامة UCB دون-خطّيّة $O(\sqrt{KT\ln T})$.

جدول الرموز

الرمز	المعنى
$\hat{\mu}_a$	تقدير متوسّط مكافأة الفعل a
N_a	عدد مرّات سحب a
$R(T)$	الندامة التراكميّة
$\mu^\star$	أفضل متوسّط مكافأة

الرسم

<figure> الشكل<figcaption> 6.44: رفعت التفاؤل (UCB) تجعل الأذرع غير المؤكّدة تُجرَّب قبل استغلال



شكل ٦.٤٤: *
استكشاف واستغلال

الأفضل.</figcaption> </figure>

البرهان

الخطوة 1 (الندامة كمقياس): الندامة تجمع خسارة الأزرار دون الأمثلي عبر الزمن. ■

الخطوة 2 (حدود تركين): بهوفدنغ، $P(|\hat{\mu}_a - \mu_a| > \varepsilon) \le 2e^{-2N_a\varepsilon^2} \Rightarrow$ نصف قطر ثقة $\sqrt{\ln t / 2N_a}$. ■

الخطوة 3 (التفاؤل): إضافة حدّ الثقة (UCB) يدفع لتجربة الأفعال غير المؤكّدة؛ المعايرة بين ε (استكشاف) والفجوة (الاستغلال). ■

خمسة عشر مثالاً محلولاً

مثال (1-7.44): ندامة جشعة المعطيات: $\mu^\star = 0.9$، الفعل المختار $\mu = 0.6$، $T = 100$. المطلوب: الندامة لو اخترناه دائماً. الحل: الخطوة 1: الفجوة $0.3 = 0.9 - 0.6$؛ ندامة $= 0.3 \times 100 = 30$. النتيجة: 30. الربط بالذكاء الاصطناعي: الاستغلال الأعمى مكلف.

مثال (2-7.44): ندامة ε-greedy المعطيات: $K = 5$ أذرع، $\varepsilon = 0.1$، $T = 1000$، فجوة متوسّطة 0.2. المطلوب: حدّ نموذجيّ. الحل: الخطوة 1: الجزء الخطّيّ $\varepsilon T = 0.1 \times 1000 = 100$؛ الجزء التقريبيّ $\frac{K}{\varepsilon} \times \ldots$. النتيجة: نحو $+100$ (خطّيّ في T). الربط بالذكاء الاصطناعي: ε ثابت $\Rightarrow$ ندامة خطّية.

مثال (3-7.44): ندامة UCB المعطيات: $K = 5, T = 1000$، $\ln T \approx 6.9$. المطلوب: مرتبة الندامة. الحل: الخطوة 1: $\sqrt{KT\ln T} = \sqrt{5 \times 1000 \times 6.9} = \sqrt{34500} \approx 186$. النتيجة: نحو $\sqrt{KT\ln T}$ (دون-خطّيّة). الربط بالذكاء الاصطناعي: الندامة تنمو كـ $\sqrt{T}$ لا T.

مثال (4-7.44): ε-decay المعطيات: $\varepsilon_t = 1/t$، $T = 1000$. المطلوب: نوع الندامة. الحل: الخطوة 1: يتقارب إلى الاستغلال؛ ندامة دون-خطّية (لوغاريتميّة). النتيجة: دون-خطّية. الربط بالذكاء الاصطناعي: تفتيت الاستكشاف.

مثال (5-7.44): ثقة هوفدنغ المعطيات: $\delta = 0.05$، $\varepsilon = 0.1$، $N_a = 1000$. المطلوب: تحقّق $2e^{-2N\epsilon^2}$. الحل: الخطوة 1: $2e^{-2\times 1000\times 0.01} = 2e^{-20} = 2\times 2\times 10^{-9} = 4\times 10^{-9} < 0.05 = \delta$؟ النتيجة: يتحقّق. الربط بالذكاء الاصطناعي: تركيز العيّنات.

مثال (6-7.44): عيّنات لازمة المعطيات: نريد خطأ $\varepsilon = 0.05$ باحتمال 0.95. المطلوب: N (حدّ هوفدنغ). الحل: الخطوة 1: $N \approx \frac{\ln(2/\delta)}{2\varepsilon^2} = \frac{\ln 40}{2\times 0.0025} = \frac{3.69}{0.005} = 738$. النتيجة: $N \approx 738$. الربط بالذكاء الاصطناعي: تعقيد العيّنات.

مثال (7-7.44): فجوة كبيرة المعطيات: $\mu_1 = 0.9, \mu_2 = 0.8$ (فجوة 0.1) وفجوة 0.5 في مقارنة أخرى. المطلوب: أيهما يحتاج عيّنات أقلّ للتمييز؟ الحل: الخطوة 1: الفجوة الكبيرة (0.5) تُكتشف بعيّنات أقلّ. النتيجة: الفجوة 0.5. الربط بالذكاء الاصطناعي: سهولة التمييز.

مثال (8-7.44): نصف قطر الثقة المعطيات: $\ln t = 6.9, N_a = 50$. المطلوب: نصف القطر $(\sqrt{\ln t/N_a})$. الحل: الخطوة 1: $\sqrt{6.9/50} = \sqrt{0.138} = 0.371$. النتيجة: 0.371. الربط بالذكاء الاصطناعي: فعالة عند قلة السحب.

مثال (9-7.44): بعد عيّنات أكثر المعطيات: $N_a = 5000$ لنفس (8-7.44). المطلوب: نصف القطر. الحل: الخطوة 1: $\sqrt{6.9/5000} = \sqrt{0.00138} = 0.037$. النتيجة: 0.037. الربط بالذكاء الاصطناعي: يتقلّص بالعيّنات.

مثال (10-7.44): عيّنة تومسون المعطيات: نماذج بايزيّة حول المتوسّط كلّ ذراع. المطلوب: القرار. الحل: الخطوة 1: نسحب من التوزيع البعديّ لكلّ ذراع ونختار الأقصى. النتيجة: تفاؤل بايزيّ. الربط بالذكاء الاصطناعي: استكشاف احتماليّ.

مثال (11-7.44): حدّ أدنى نظريّ المعطيات: لا خوارزميّة تتفوّق $\Omega(\sqrt{KT})$. المطلوب: معناه. الحل: الخطوة 1: UCB يقترب من الأمثل؛ لا تحسّن أساسيّ ممكن. النتيجة: $\Omega(\sqrt{KT})$. الربط بالذكاء الاصطناعي: حدّ لا يمكن تجاوزه.

مثال (12-7.44): تراكم الندامة المعطيات: ندامة سنويّة $\sqrt{T}$، $T = 10^4 \approx$. المطلوب: القيمة التقريبيّة (بمعامل $K = 2$، 1). الحل: الخطوة 1: $\sqrt{2\times 10^4} = 141$؛ نسبة $\frac{141}{10^4} \to 0$. النتيجة: 141 لكن نسبتها تختفي. الربط بالذكاء الاصطناعي: دون-خطّية = الأمثل.

مثال (13-7.44): ε صغير المعطيات: $\varepsilon = 0.01$، $K = 5$، $T = 10^4$. المطلوب: الجزء الاستكشافيّ. الحل: الخطوة 1: $\varepsilon T = 100$؛ لكن استكشاف ضعيف قد يحبس خياراً رديك. النتيجة: 100 (خطر البقاء). الربط بالذكاء الاصطناعي: استكشاف غير كافٍ.

مثال (14-7.44): حالة صعبة المعطيات: K أذرع متقاربة جدّاً (فجوات صغيرة). المطلوب: سلوك الندامة. الحل: الخطوة 1: ترتفع الندامة لأنّ التمييز يحتاج عيّنات أكثر. النتيجة: ندامة عالية. الربط بالذكاء الاصطناعي: صعوبة حالات قريبة.

مثال (15-7.44): خلاصة المعطيات: نريد ندامة دنيا. المطلوب: الاستراتيجيّة. الحل: الخطوة 1: تفاؤل (UCB) أو ε-decay أو تومسون؛ تجنّب ε ثابت. النتيجة: استكشاف تآكليّ. الربط بالذكاء الاصطناعي: ممارسة مثلى.

أخطاء شائعة

- **الخلط بين ε ثابت وتآكليّ:** الثابت يعطي ندامة خطّية.
- **نسيان الفجوة في الندامة:** كلّ سحب لغير الأمثل يكلّف الفجوة.
- **الظنّ أن UCB بلا نموذج:** يحتاج فقط عدّاد سحب لكلّ فعل.
- **إهمال حدّ $\sqrt{KT\ln t}$:** نصف قطر الثقة يقلّ بالسحب.

- **الخلط بين الندامة والتعقيد الحسابيّ:** هنا مقياس لعيّنات القرار لا للوقت.

صياغة رسمية: نُدرّب ممثّلاً (السياسة) وناقداً (القيمة) معاً؛ الناقد يقدّر خطّ الأساس والميزة:

$$\delta_t = r_{t+1} + \gamma V_w(s_{t+1}) - V_w(s_t), \qquad \theta \leftarrow \theta + \alpha\, \delta_t\, \nabla_\theta \log \pi_\theta(a_t|s_t) \tag{8.44}$$

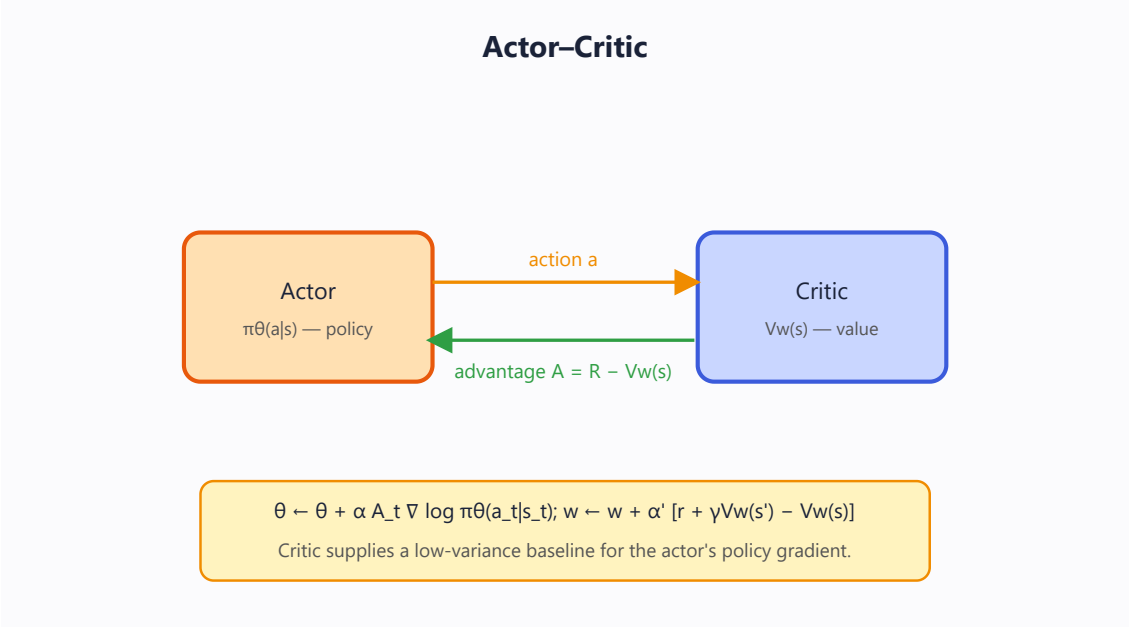
$$w \leftarrow w + \beta\, \delta_t\, \nabla_w V_w(s_t) \tag{9.44}$$

جدول الرموز

الرمز	المعنى
δ_t	خطأ الفرق الزمنيّ (TD error)
الممثّل	يحدّث θ (السياسة)
الناقد	يحدّث w (القيمة)

الرسم

<figure> الشكل<figcaption> 7.44: الناقد يوفّر الميزة (خطأ TD) كمُرجّح تباين منخفض لتحديث



شكل ٧.٤٤: *
الممثّل والناقد

الممثّل.</figcaption> </figure>

البرهان

الخطوة 1 (الميزة كمرجّح): δ_t تقدير للميزة $A^\pi(s_t, a_t)$؛ جداول تدرّج السياسة بـ $\delta \nabla \log \pi$ تُخفّض التباين مقابل العائد الخام. ■

الخطوة 2 (تحديث الناقد): الناقد يقلّص خطأ TD بحلّ تقريبيّ لمعادلة بيلمان الترقّية. ■

الخطوة 3 (التدريب المشترك): الممثّل يتبع التدرّج استناداً إلى تقدير الناقد؛ يتقاربان معاً. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.44): خطأ TD المعطيات: $V_w(s)=3$، $V_w(s')=5$، $\gamma=0.9$، $r_{t+1}=1$. المطلوب: δ_t. الحل: الخطوة 1: $\delta=1+0.9\times5-3=1+4.5-3=2.5$. النتيجة: 2.5. الربط بالذكاء الاصطناعي: أفضل من المتوقّع.

مثال (2-8.44): خطأ سالب المعطيات: $V_w(s)=4$، $V_w(s')=1$، $r=0$، $\gamma=0.9$. المطلوب: δ_t. الحل: الخطوة 1: $0+0.9\times1-4=0.9-4=-3.1$. النتيجة: -3.1. الربط بالذكاء الاصطناعي: أسوأ من المتوقّع.

مثال (3-8.44): تحديث الناقد المعطيات: $V_w(s)=3$، $\delta=2.5$، $\beta=0.2$. المطلوب: $V_{new}(s)$. الحل: الخطوة 1: $3+0.2\times2.5=3+0.5=3.5$. النتيجة: 3.5. الربط بالذكاء الاصطناعي: يرتفع نحو القيمة الفعليّة.

مثال (4-8.44): تحديث الممثّل المعطيات: $\delta=2.5$، $\nabla\log\pi(a|s)=(0.4,-0.4)$ لاختيار a، $\alpha=0.1$. المطلوب: اتجاه $\Delta\theta$. الحل: الخطوة 1: $0.1\times2.5\times(0.4,-0.4)=0.25\times(0.4,-0.4)=(0.1,-0.1)$. النتيجة: $(0.1,-0.1)$ يرفع احتمال a. الربط بالذكاء الاصطناعي: تعزيز الفعل المفضّل.

مثال (5-8.44): ميزة متناقصة المعطيات: $\delta\to0$ عند التقارب. المطلوب: سلوك تحديث الممثّل. الحل: الخطوة 1: يتقلّص إلى الصفر (لا مكسب إضافيّ). النتيجة: ثبات عند الأمثل. الربط بالذكاء الاصطناعي: استقرار.

مثال (6-8.44): عائد n-خطوات المعطيات: $r_1=1, r_2=0.5$، $V(s_2)=4$، $\gamma=0.9$. المطلوب: $G_{t:t+2}$. الحل: الخطوة 1: $1+0.9\times0.5+0.9^2\times4=1+0.45+3.24=4.69$. النتيجة: 4.69. الربط بالذكاء الاصطناعي: عائد متعدّد الخطوات.

مثال (7-8.44): الميزة المعمّمة المعطيات: $\gamma=0.9$، $\lambda=0.95$، GAE $=(1-\lambda)\sum_k(\gamma\lambda)^k\delta_{t+k}$. المطلوب: معامل $\gamma\lambda$. الحل: الخطوة 1: $\gamma\lambda=0.855$ (تخفيف متسارع). النتيجة: 0.855. الربط بالذكاء الاصطناعي: موازنة انحياز/تباين.

مثال (8-8.44): A2C مقابل A3C المعطيات: A2C متزامن؛ A3C غير متزامن بعدة عاملين. المطلوب: الفرق العمليّ. الحل: الخطوة 1: A3C يحدّث شيئاً من التزامن غير المتّسق؛ A2C أبسط وأكثر استقراراً دفعاته. النتيجة: A2C متزامن. الربط بالذكاء الاصطناعي: تنفيذ عمليّ.

مثال (9-8.44): تباين مرتفع بدون ناقد المعطيات: عائد REINFORCE $\hat{G}$ بتباين 64؛ ناقد يخفضه إلى 4. المطلوب: التحسّن. الحل: الخطوة 1: التباين أقلّ بـ16 مرّة $\Rightarrow$ تحديثات أدقّ. النتيجة: انخفاض $16\times$. الربط بالذكاء الاصطناعي: فائدة الناقد.

مثال (10-8.44): ناقد نخطّ أساس المعطيات: $V(s)=3$ كأساس بدل المتوسّط. المطلوب: لماذا أفضل؟ الحل: الخطوة 1: $V(s)$ يعتمد على الحالة لا على الفعل $\Rightarrow$ أساس أدقّ لكلّ حالة. النتيجة: أساس معتمد على الحالة. الربط بالذكاء الاصطناعي: تباين أقلّ.

مثال (11-8.44): هدف مشترك المعطيات: خسارة الممثّل $-\delta\log\pi$؛ خسارة الناقد $\frac{1}{2}\delta^2$. المطلوب: الهدف الكلّيّ. الحل: الخطوة 1: $\mathcal{L}=-\delta\log\pi+\frac{1}{2}\delta^2$ (بتقدير δ). النتيجة: مجموع الهدفين. الربط بالذكاء الاصطناعي: تدريب مشترك.

مثال (12-8.44): ناقد Q مقابل V المعطيات: يمكن للناقد تقدير $Q(s,a)$ بدل $V(s)$. المطلوب: الفرق. الحل: الخطوة 1: ناقد V أخفّ (بلا فعل)؛ Q أدقّ لكن أكبر. النتيجة: V أخفّ. الربط بالذكاء الاصطناعي: اختيار التمثيل.

مثال (13-8.44): كفاءة العيّنات المعطيات: الممثّل–الناقد يعيد استخدام العيّنات أكثر. المطلوب: لماذا؟ الحل: الخطوة 1: ناقد يُعلّم قيمة من نفس الانتقالات $\Rightarrow$ عيّنات إضافيّة. النتيجة: كفاءة أعلى. الربط بالذكاء الاصطناعي: عيّنات مشتركة.

مثال (14-8.44): استقرار التدريب المعطيات: α,β متوازنان. المطلوب: خطأ شائع. الحل: الخطوة 1: ناقد بطيء $\Rightarrow$ ممثّل بتدرّج صاخب؛ يلزم توازن. النتيجة: توازن معدّلين. الربط بالذكاء الاصطناعي: ضبط α,β.

مثال (15-8.44): خلاصة المعطيات: $\delta=r+\gamma V(s')-V(s)$. المطلوب: دوره. الحل: الخطوة 1: يقدّر الميزة ويوجّه الممثّل ويصحّح الناقد. النتيجة: محرّك مشترك. الربط بالذكاء الاصطناعي: قلب الممثّل–الناقد.

أخطاء شائعة

- **نسيان تحديث الناقد:** بلا قيمة لا ميزة ولا تدرّج سليم.
- **الخلط بين δ والعائد الخامّ:** δ مقايضة انحياز/تباين منخفض.
- **تجاهل توازن α, β:** عدمه يُفسد الاستقرار.
- **الظنّ أن $\delta = 0$ عند الأمثل دائماً:** يقارب الصفر قرب تلبية المعادلة.
- **الخلط بين A2C وA3C:** تزامن مقابل تزامنيّة غير متّسقة.

جدول تجميع النظريات

النظرية	العنوان	المعادلة المحوريّة	الرسم
2.44	MDP والقيم	$G_t = \sum \gamma^k r_{t+k+1}$	fig-4401
3.44	أمثلية بيلمان	$V^\star = \max_a \sum P(R + \gamma V^\star)$	fig-4402
4.44	تكرار القيمة/السياسة	$V_{k+1} = \mathcal{T} V_k$	fig-4403
5.44	Q-learning	$Q + \alpha[r + \gamma \max Q - Q]$	fig-4404
6.44	تدرّج السياسة	$\nabla J = E[\sum \nabla \log \pi \, G]$	fig-4405
7.44	الاستكشاف والندامة	ε-greedy؛ UCB	fig-4406
8.44	الممثّل–الناقد	$\delta = r + \gamma V(s') - V(s)$	fig-4407

عشرون تمريناً محلولاً (إجابات موجزة)

١. **(عائد)** $r = 1, \gamma = 0.5$ دائم — $V = 2$.

٢. **(عائد)** $\gamma = 0.9$ — $V = 10$.

٣. **(go/stay)** $V^\star(S_0)$ (لـ3.44-1) — 1.

٤. **(Q أمثل)** $Q(\text{stay}) = 0.9V$ — 0.9 عند $V = 1$.

٥. **(PI)** عدد السياسات الحتميّة 2^n — 2^n.

٦. **(VI)** $\gamma = 0.9$، $0.9^k < 0.01$ — $k = 44$.

٧. **(VI)** $\gamma = 0.5$ — حتى 0.01 — $k = 7$.

٨. **(معامل)** $\gamma = 0.9$ — $\frac{\gamma}{1-\gamma} = 9$.

٩. **(Q)** $Q = 0.5, r = 1, \max Q = 2, \alpha = 0.1$ — 0.73.

١٠. **(Q سريع)** $\alpha = 0.5$ لنفس — 1.65.

١١. **(SARSA)** فعليّ 0.4 مقابل أقصى 1.0 — هدفا $0.36, 0.9$.

١٢. **(ϵ-greedy)** $\varepsilon = 0.1$، 4 أفعال — أفضل 0.925.

١٣. **(REINFORCE)** $\pi = (0.6, 0.4)$، $G = (10, 2)$ — أساس 6.8.

١٤. **(REINFORCE)** المزايا — $A = (3.2, -4.8)$.

١٥. **(نقطة)** $\gamma = 0.9$، $k = 90 - \ln 0.01 / \ln 0.95$.

١٦. **(ندامة)** $T = 100, \mu = 0.6, \mu^\star = 0.9$ جشع — 30.

١٧. **(UCB)** $K = 5, T = 1000$ — ≈ 186.

١٨. **(TD)** $V = 3, r = 1, V' = 5, \gamma = 0.9$ — TD 2.5.

١٩. **(الناقد)** $\beta = 0.2$، TD، 2.5، $V = 3$ — $V = 3.5$.

٢٠. **(خلاصة)** ناقد خفّض التباين من 64 إلى 4 — $\times 16$.

فهرس الرموز

الرمز	المعنى	أول ورود
γ	عامل الخصم	2.44
V^π, Q^π	القيم تحت π	2.44
$V^\star, Q^\star$	القيم الأمثلى	3.44
$\mathcal{T}$	معامل بيلمان	4.44
α	معدّل التعلّم	5.44
$b(s)$	خطّ أساس	6.44
δ_t	خطأ TD	8.44

المراجع

- Barto, R., Sutton, A. (2018). *Reinforcement Learning: An Introduction*. MIT Press.
- Bellman, R. (1957). *Dynamic Programming*. Princeton University Press.
- Watkins, C., Dayan, P. (1992). *Machine Learning* 8(3): Q-learning.
- Williams, R. (1992). *Simple Statistical Gradient-Following Algorithms*. Machine Learning.
- Mnih, V. et al. (2015). *Human-Level Control Through Deep Reinforcement Learning*. Nature. (*DQN*)
- Schulman, J. et al. (2016). *High-Dimensional Continuous Control Using Generalized Advantage Estimation*. ICLR Workshop.

نظرية الألعاب والتعلّم الاستراتيجي

«عندما يتعلّم عدّة وكلاء معاً، كلّ واحدٍ يتعامل مع خصومٍ يتعلّمون، لم يبقَ البيئة ثابتة بل أصبحت ذات مصالح متعارضة.»

التعلّم الإشرافيّ والتعزيزيّ المفرد يفترضان بيئة ساكنة. لكن في الأسواق والألعاب والروبوتات المتعدّدة، الوكيل يواجه خصوماً عقلانيّين. تُحلّل نظرية الألعاب هذا الصراع: التوازن الناشيّ، الألعاب ثنائيّة الصفر، ديناميكيات التعلّم، تقليل الندامة المضادّ، ألعاب الإمكانات، والتعلّم متعدّد الوكلاء.
سبع نظريات:

- **2.45 الصياغة العادية وتوازن ناش** — $G=(N,(A_i),(u_i))$؛ لا يستطيع أحد التحسّن أحاديّاً.
- **3.45 نظريّة ناش للوجود** — كلّ لعبة منتهية لها توازن ناش مُخالط.
- **4.45 الألعاب ثنائيّة الصفر والحدّ الأدنى-الأقصى** — $\max_p \min_q p^\top M q = \min_q \max_p p^\top M q = v$.
- **5.45 ديناميكيات التعلّم** — اللعب الوهميّ، ديناميكيات المنسوخ، أفضل استجابة.
- **6.45 الندامة وCFR** — تعلّم بلا ندمة $\Rightarrow$ متوسط الاستراتيجيّة توازن ناشيّ ε.
- **7.45 ألعاب الإمكانات والازدحام** — وجود توازن ناشٍ نقيّ عبر دالّة إمكان.
- **8.45 التعلّم متعدّد الوكلاء واللعب الذاتيّ** — عدم الثبات واللعب مقابل الذات.

كلّ نظرية تتبع القالب: صياغة رسمية $\longleftarrow$ جدول رموز $\longleftarrow$ رسم $\longleftarrow$ برهان $\longleftarrow$ خمسة عشر مثالاً $\longleftarrow$ أخطاء شائعة.

الرمز	المعنى	ملاحظة
N	مجموعة اللاعبين	$\|N\|=n$
A_i	أفعال اللاعب i	
u_i	منفعة اللاعب i	$u_i: A\to\mathbb{R}$
σ_i	استراتيجيّة مُخالطة	في $\Delta(A_i)$
$\Delta(A_i)$	المِجْمَز	توزيع احتمالات على A_i

الاتفاقيات: $A=\prod_i A_i$ ملفّ الأكوان، العائد تحت σ هو التوقّع على الأفعال. كلّ المعادلات في كتل LTR.

صياغة رسمية: لعبة عادية $G=(N,(A_i)_{i\in N},(u_i)_{i\in N})$، ملفّ استراتيجيّات $\sigma=(\sigma_i)$ توازن ناشيّ (NE) إذا:

$$u_i(\sigma_i^\star,\sigma_{-i}^\star)\ \geq\ u_i(\sigma_i,\sigma_{-i}^\star)\qquad \forall\,\sigma_i,\ \forall i \tag{1.45}$$

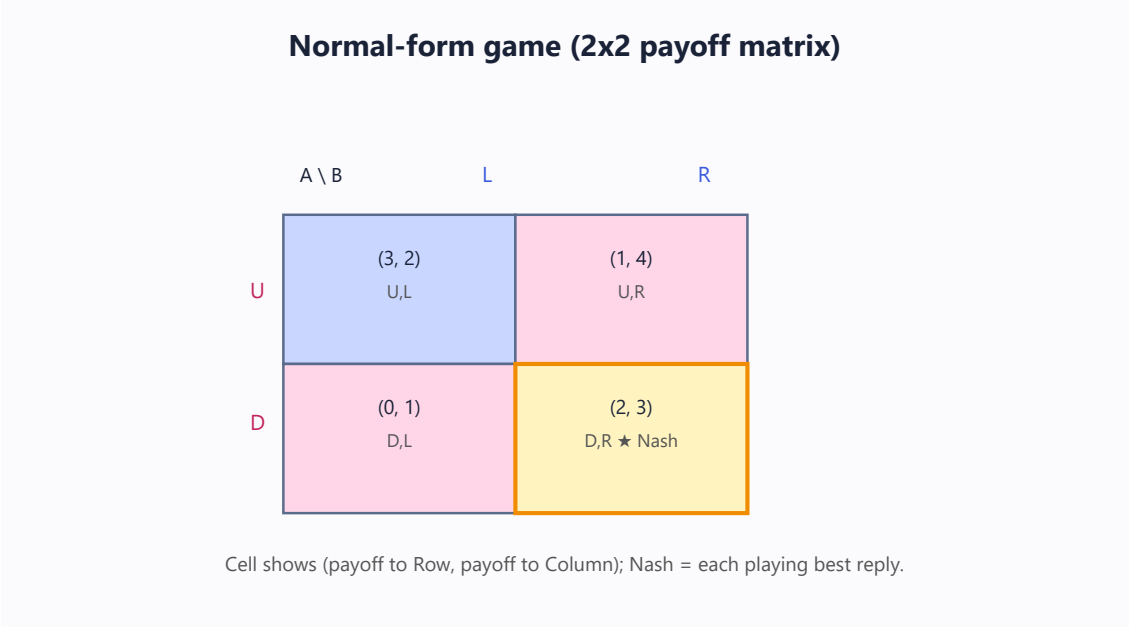
أي لا يحسّن أحد بانحرافه أحاديّاً.

جدول الرموز

الرمز	المعنى
σ_{-i}	استراتيجيّات الآخرين
أفضل استجابة	$BR_i(\sigma_{-i}) = \arg\max_{\sigma_i} u_i$
NE	تقاطع أفضل الاستجابات

الرسم

<figure> الشكل<figcaption> 1.45: مصفوفة منافع لاعبيْن؛ الخانة (D,R) توازن ناشٍ لأنّ كلاً منهما يلعب أفضل



شكل ١.٤٥: *
مصفوفة اللعبة

استجابة للآخر.</figcaption> </figure>

البرهان

الخطوة 1 (أفضل استجابة): كلّ لاعب يختار $\arg\max u_i$ مع تثبيت البقيّة. ■

الخطوة 2 (التوازن): NE نقطة تبادليّة: $\sigma_i^\star \in BR_i(\sigma_{-i}^\star)$ لكلّ i. ■

الخطوة 3 (الاستقرار): لا حافز لانحراف منفرد $\Rightarrow$ استقرار ذاتيّ تحت العقلانيّة. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.45): البحث عن Nash المعطيات: المصفوفة من الشكل 1.45: $(3,2)$ = (U,L)، $(1,4)$ = (U,R)، $(0,1)$ = (D,L)، $(D,R) = (2,3)$. المطلوب: توازن ناشٍ نقيّ. الحل: الخطوة 1: عند (D,R): اللاعب-1 لو غيّر إلى U يحصل $2 > 1$ (لا ينحرف)؛ للاعب-2 تغيير إلى L يعطي $3 > 1$ (لا ينحرف). النتيجة: (D,R) توازن ناشٍ نقيّ. الربط بالذكاء الاصطناعي: مثال كلاسيكيّ ثابت.

مثال (2-2.45): أفضل استجابة للاعب الصفّ المعطيات: إذا لعب العمود L: 0 $U = 3, D = 0$. المطلوب: $BR_{\text{صفّ}}(L)$. الحل: الخطوة 1: $\arg\max(3,0) = U$. النتيجة: U. الربط بالذكاء الاصطناعي: ردّ على L.

مثال (45.2-3): أفضل استجابة للاعب الصفّ (2) المعطيات: إذا لعب العمود R: $U = 1, D = 2$. المطلوب: $BR_{\text{صفّ}}(R)$. الحل: الخطوة 1: $\arg\max(1, 2) = D$. النتيجة: D. الربط بالذكاء الاصطناعي: يتبع R.

مثال (45.2-4): أفضل استجابة للعمود المعطيات: إذا لعب الصفّ U: $L = 2, R = 4$. المطلوب: $BR_{\text{عمود}}(U)$. الحل: الخطوة 1: $\arg\max(2, 4) = R$. النتيجة: R. الربط بالذكاء الاصطناعي: يردّ على U.

مثال (45.2-5): العائد عند التوازن المعطيات: $(2, 3) = (D, R)$. المطلوب: منفعة كلّ لاعب عند Nash. الحل: الخطوة 1: اللاعب-1 يحصل 2؛ اللاعب-2 يحصل 3. النتيجة: $(2, 3)$. الربط بالذكاء الاصطناعي: نتيجة التبادل.

مثال (45.2-6): استراتيجيّة مُخالطة المعطيات: اللاعب-1 يلعب U باحتمال p؛ العمود L باحتمال $0.5 = q$. المطلوب: العائد المتوقّع للاعب-1. الحل: الخطوة 1: $p(0.5 \cdot 3 + 0.5 \cdot 1) + (1 - p)(0.5 \cdot 0 + 0.5 \cdot 2) = p(2) + (1 - p)(1) = 2p + 1 - p = p + 1$. النتيجة: $p + 1$ (يزيد مع p). الربط بالذكاء الاصطناعي: عائد تحت العشو.

مثال (45.2-7): مفرّد السجن المعطيات: $(3, 3) = (C, C)$، $(0, 5) = (C, D)$، $(5, 0) = (D, C)$، $(1, 1) = (D, D)$. المطلوب: Nash والاستراتيجيّة المفرّدة. الحل: الخطوة 1: D مفرّدة لكلّ لاعب (5>3 مقابل C؟ والانحراف). عند (D, D) لا انفراد. النتيجة: (D, D) لكنّه غير فعّال اجتماعيّاً. الربط بالذكاء الاصطناعي: توازن دون الأمثل الجمعيّ.

مثال (45.2-8): مقارنة بفعّال اجتماعيّاً المعطيات: (C, C) مجموع 6 مقابل (D, D) مجموع 2. المطلوب: الفجوة. الحل: الخطوة 1: $6 - 2 = 4$ (خسارة اجتماعيّة). النتيجة: 4. الربط بالذكاء الاصطناعي: سعر الفردانيّة.

مثال (45.2-9): استراتيجيّة مفرّدة المعطيات: D يحسّن مقابل أيّ شيء. المطلوب: التحقّق من مفرّد. الحل: الخطوة 1: $u(D, \cdot) \geq u(C, \cdot)$ لكلّ أعمدة $\Rightarrow D$ مفرّدة. النتيجة: مفرّدة. الربط بالذكاء الاصطناعي: لا يحتاج تخمين الخصم.

مثال (45.2-10): عدم وجود Nash نقيّ المعطيات: مطابقة بنسات: الصفّ يريد التطابق، العمود يريد الاختلاف؛ $(H, H), (T, T)$ يفوز فيهما الصفّ (1-,1)؛ $(H, T), (T, H)$ العمود. المطلوب: هل يوجد Nash نقيّ؟ الحل: الخطوة 1: في أيّ خانة أحد يريد التغيير $\Rightarrow$ لا Nash نقيّ. النتيجة: لا يوجد. الربط بالذكاء الاصطناعي: يحتاج تخالطًا.

مثال (45.2-11): توازن مُخالط في البنسات المعطيات: المصفوفة المعتادة للمطابقة-المعارضة. المطلوب: الاستراتيجيّات. الحل: الخطوة 1: كلاهما يلعب H باحتمال 0.5 (يجعل الآخر غير متمايز). النتيجة: $(0.5, 0.5)$. الربط بالذكاء الاصطناعي: Nash مُخالط.

مثال (45.2-12): توافق (معركة الأجناس) المعطيات: $(2, 1) = (O, O)$، $(1, 2) = (F, F)$، $(P, P) = (0, 0)$؛ أعداد مختلفة لتفضيلات. المطلوب: توازنات ناشٍ نقيّة. الحل: الخطوة 1: (O, O) توازن (لا انفراد) و(F, F) توازن. النتيجة: توازنان نقيّان. الربط بالذكاء الاصطناعي: تنسيق واصطفاء.

مثال (45.2-13): العائد عند التوافق المعطيات: $(O, O) = (2, 1)$. المطلوب: قيمة كلّ لاعب. الحل: الخطوة 1: اللاعب-1 يحصل 2، اللاعب-2 يحصل 1. النتيجة: $(2, 1)$. الربط بالذكاء الاصطناعي: تنسيق غير متناظر.

مثال (45.2-14): الاعتماد على العشو المتبادل المعطيات: لعبة تنسيق باحتمال اختيار غير متناسق. المطلوب: سلوك العائد. الحل: الخطوة 1: احتمال عدم التطابق يُنقص العائد لكليهما. النتيجة: يفضّلان التناسق. الربط بالذكاء الاصطناعي: قيمة التواصل.

مثال (45.2-15): خلاصة المعطيات: مصفوفة عامّة 2×2. المطلوب: كيف نجد Nash نقيّ؟ الحل: الخطوة 1: نبحث عن خانة يكون فيها كلّ رقم أعلى قيمة في صفّه/عموده. النتيجة: فحص بسيط. الربط بالذكاء الاصطناعي: خوارزميّة مباشرة.

أخطاء شائعة

- **الخلط بين Nash والكفاءة الاجتماعيّة:** Nash ليس بالضرورة الأمثل جمعاً (مثل مفرّد السجن).
- **نسيان أن NE أحاديّ الانحراف:** لا تُقيَّم بانحرافات متعدّدة.
- **الظنّ أن كلّ لعبة لها Nash نقيّ:** بعضها له مُخالط فقط (المطابقة-المعارضة).
- **الخلط بين أفضل استجابة والاستراتيجيّة المفرّدة:** الأخيرة لا تعتمد على الخصم.
- **نسيان أن العائد توقّع عند الاختلاط:** الرقم في الخانة هو المتوقّع.

صياغة رسمية: لكلّ لعبة منتهية (عدد لاعبين منتهٍ وأفعال منتهية)، يوجد توازن ناشٍ على الأقلّ في الاستراتيجيّات المُخالطة (ناش 1950):

$$\exists\, \sigma^\star \in \prod_i \Delta(A_i) \text{ بحيث } \sigma_i^\star \in BR_i(\sigma_{-i}^\star)\ \ \forall i \tag{2.45}$$

جدول الرموز

الرمز	المعنى
$\Delta(A_i)$	المِجْهَز (محدّب مضغوط)
BR	مطابَق أفضل استجابة (كاكوتاني)
نقطة ثابتة	$\sigma \in BR(\sigma)$

الرسم

<figure> الشكل<figcaption> 2.45: توازنات ناش هي نقاط تقاطع منحنياتيّ أفضل استجابة؛ نظريّة كاكوتاني تضمن وجوداً.</figcaption> </figure>

البرهان

الخطوة 1 (مطابقة أفضل استجابة): لكلّ σ_{-i}، BR_i غير خالية (أفضل استجابة لاتصالك). ■

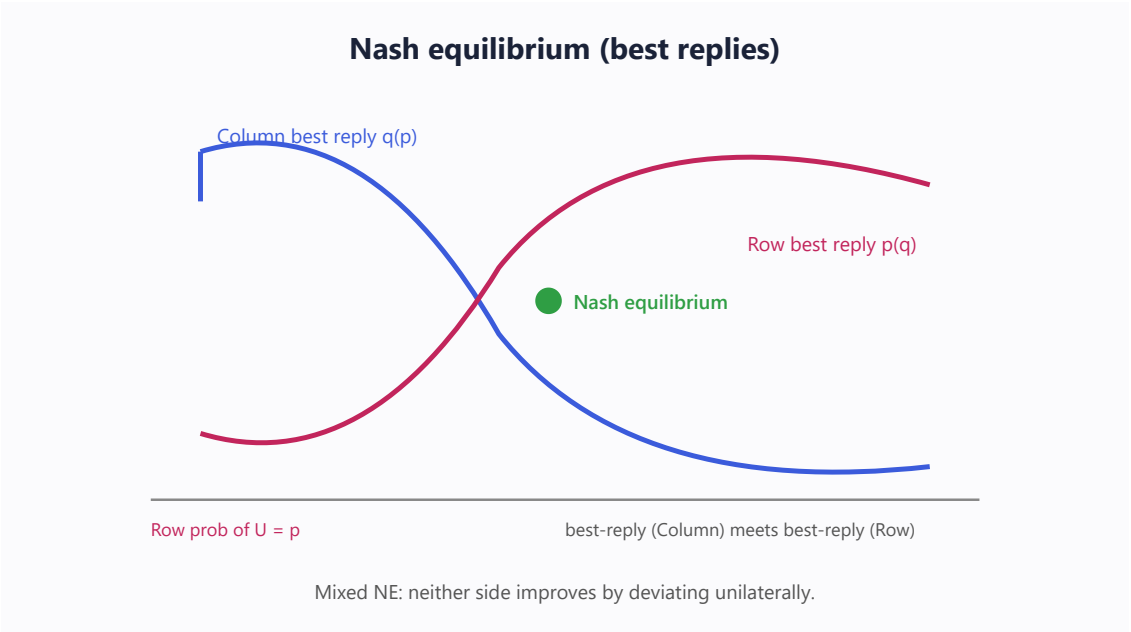
الخطوة 2 (قيم محدّبة): u_i خطّيّة في σ_i و$\Delta(A_i)$ محدّب $\Rightarrow$ قيم BR_i محدّبة. ■

الخطوة 3 (كاكوتاني): المطابقة BR نصف-متصلة علوياً بقيم محدّبة غير خالية على مضغوط محدّب $\Rightarrow$ نقطة ثابتة (توازن ناش). ■

خمسة عشر مثالاً محلولاً

مثال (3.45-1): ضمان الوجود المعطيات: لعبة منتهية عامّة. المطلوب: مضمون ناش. الحل: الخطوة 1: يوجد توازن ناشٍ مُخالط على الأقلّ. النتيجة: مضمون. الربط بالذكاء الاصطناعي: أساس نظريّ للتعلّم.

مثال (3.45-2): لعبة البنسات المعطيات: المطابقة-المعارضة (لا Nash نقيّ). المطلوب: توازن مُخالط. الحل: الخطوة 1: كلاهما يلعب H باحتمال 0.5، القيمة 0. النتيجة: توازن وحيد $(0.5, 0.5)$. الربط بالذكاء الاصطناعي: وجود رغم غياب النقيّ.



شكل ٢٠٤٥: *
توازن ناش

مثال (3-3.45): قيمة التوازن المُخالط المعطيات: مطابقة بنسات،$\sigma = (0.5, 0.5)$. المطلوب: العائد لكلّ لاعب. الحل: الخطوة 1: $\mathbb{E}[u_{\text{صفّ}}] = 0.25(1) + 0.25(-1) + 0.25(-1) + 0.25(1) = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: عادل.

مثال (4-3.45): عدد فرديّ المعطيات: لعبة عامّة (نتيجة ويلسون). المطلوب: عدد التوازنات. الحل: الخطوة 1: عدد التوازنات (مع الشروط) فرديّ غالباً. النتيجة: فرديّ (غالباً). الربط بالذكاء الاصطناعي: نتيجة بنيويّة.

مثال (5-3.45): توافق محتلم المعطيات: لعبة تنسيق بحالات وسطى. المطلوب: السلوك. الحل: الخطوة 1: كثيرة توازنات متصلة (مقطع من Nash). النتيجة: سلسلة توازنات. الربط بالذكاء الاصطناعي: انحلال.

مثال (6-3.45): محدّبية المِجْهَز المعطيات: $\Delta(A)$. المطلوب: لماذا مهمّة؟ الحل: الخطوة 1: يمكّن تطبيق كاكوتنيّ (لقيم BR المحدّبة) من إثبات نقطة ثابتة. النتيجة: شرط جوهريّ. الربط بالذكاء الاصطناعي: سبب اللجوء للمُخالط.

مثال (7-3.45): نصف-استمراريّة المعطيات مطابقة BR. المطلوب: الشرط المطلوب. الحل: الخطوة 1: نصف-استمراريّة علويّة (قيم مغلقة عند النهايات). النتيجة: يتحقّق بمنافع المستمرّة. الربط بالذكاء الاصطناعي: معايير كاكوتاني.

مثال (8-3.45): لعبة تناظريّة المعطيات: $u_i(\sigma) = u(\sigma_i, \dots)$ بلورة. المطلوب: نمط التوازن. الحل: الخطوة 1: توازن متماثل (كلّ اللاعبين نفس الاستراتيجيّة). النتيجة: توازن تماثليّ. الربط بالذكاء الاصطناعي: تناظر يبسّط.

مثال (9-3.45): كثرة التوازنات المعطيات: لعبة بعدّة توافقيات. المطلوب: المشكلة. الحل: الخطوة 1: كثرة التوازنات ⇒ حاجة لمعيار اختيار (اصطفاء). النتيجة: مشكلة اصطفاء. الربط بالذكاء الاصطناعي: ما التوازن المتوقّع؟

مثال (10-3.45): صعوبة الحساب المعطيات: إيجاد Nash في ألعاب عامّة. المطلوب: التعقيد. الحل: الخطوة 1: مسألة كاملة؛-PPAD لا يُعرف خوارزم متعدّد حدود عامّة. النتيجة: .صعب-PPAD الربط بالذكاء الاصطناعي: مبرّر التعلّم التقريبيّ.

مثال (11-3.45): إعادة الاصطفاء المعطيات: لعبة ذات توازنين أحدهما أفضل اجتماعيّاً. المطلوب: أيّ يختاره التعلّم؟ الحل: الخطوة 1: يعتمد على الديناميكيّة والتوافق. النتيجة: يعتمد على السياق. الربط بالذكاء الاصطناعي: ديناميكيّ

لا سكونيّ.

مثال (12-3.45): ثبات المحدّب المعطيات: $\lambda\sigma + (1-\lambda)\sigma' \in \Delta$. المطلوب: التحقّق. الحل: الخطوة 1: المِجْهَز محدّب بحكم التعريف. النتيجة: محدّب. الربط بالذكاء الاصطناعي: يسمح بالمُخالط.

مثال (13-3.45): لا وجود بلا مُخالط المعطيات: البنسات. المطلوب: توضيح. الحل: الخطوة 1: لا يوجد نقيّ؛ لذلك المُخالط ضروريّ للوجود. النتيجة: المُخالط يضمنه. الربط بالذكاء الاصطناعي: تعميم القيمة.

مثال (14-3.45): تطبيق التعلّم المعطيات: خوارزميّات التعلّم تهدف لمتوسّط ε-Nash. المطلوب: العلاقة. الحل: الخطوة 1: لا نهائيّة $\Rightarrow$ متوسط يتقارب إلى NE تقريباً. النتيجة: ربط نظريّ-حسابيّ. الربط بالذكاء الاصطناعي: أساس (6.45).

مثال (15-3.45): خلاصة المعطيات: لعبة منتهية. المطلوب: المضمون. الحل: الخطوة 1: وجود توازن مُخالط مضمون دائماً. النتيجة: مضمون. الربط بالذكاء الاصطناعي: حجر الأساس.

أخطاء شائعة

- **الظنّ أن الضمان لنقيّ:** الضمان للمُخالط فقط.
- **نسيان شرط المنتهيّة:** لا هوامش تخصّ الألعاب غير المنتهية.
- **الخلط بين الوجود والوحدانيّة:** قد تكون توازنات متعدّدة.
- **إهمال محدّبية Δ:** محدّبيّة شرط-كاكوتاني.
- **الظنّ أن الحساب متعدّد الحدود:** إيجاد Nash .صعب-PPAD

صياغة رسمية: في اللعبة ثنائية الصفر (منفعة أحدهما = نقيض الآخر) بمصفوفة M للاعب-1:

$$v = \max_{p \in \Delta} \min_{q \in \Delta} p^\top M q = \min_{q \in \Delta} \max_{p \in \Delta} p^\top M q \tag{3.45}$$

حيث v قيمة اللعبة، والاستراتيجيّات المثلى تشكّل "نقطة السرج".

جدول الرموز

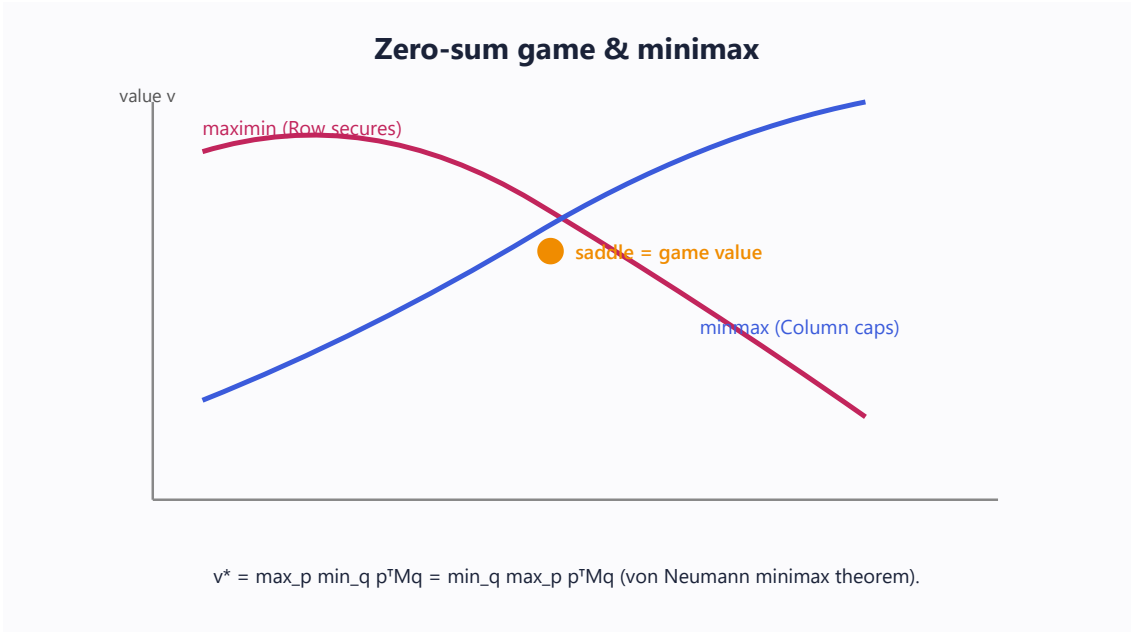
الرمز	المعنى
M	مصفوفة منافع اللاعب-1
max min	يضمن اللاعب-1 حدّاً أدنى
min max	يحاول اللاعب-2 تحديد السقف
v	قيمة اللعبة

الرسم

<figure> الشكل<figcaption> 3.45: في نقطة السرج يتساوى حدّ اللاعب-1 الأدنى وسقف اللاعب-2 الأعلى = قيمة اللعبة.</figcaption> </figure>

البرهان

الخطوة 1 (مجموعتان): وتر ط Δ مضغوط محدّب، $p^\top M q$ ثنائيّة خطّيّة. ■



شكل ٤٥.٣: *
ثنائيّة الصفر

الخطوة 2 (تبادل min/max): كونكيف-مقعّرة $p^\top Mq$ (minimax فون-نيومان theorem) $\Rightarrow \max\min = \min\max$. ■

الخطوة 3 (السرج): عند $(p^\star, q^\star)$ المثاليّين، لا يحسّن أحدهما $\Rightarrow$ توازن ناشٍ وقيمة v. ■

خمسة عشر مثالاً محلولاً

مثال (45.4-1): قيمة بنسات المطابقة المعطيات: $M = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$. المطلوب: v عبر max min. الحل: الخطوة 1: $p^\top M = [2p-1,\ 1-2p]$، $\min(2p-1, 1-2p)$؛ الأعظم عند $2p-1 = 1-2p \Rightarrow p = 0.5$. النتيجة: $v = 0$. الربط بالذكاء الاصطناعي: لعبة عادلة.

مثال (45.4-2): مصفوفة غير متماثلة المعطيات: $M = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$، $p^\top M = [2p,\ 1-p]$. المطلوب: v. الحل: الخطوة 1: $\min(2p, 1-p)$؛ أعظم عند $2p = 1-p \Rightarrow p = 1/3$. الخطوة 2: $v = 2/3 \approx 0.667$. النتيجة: $v = 2/3$. الربط بالذكاء الاصطناعي: مزيج أمثليّ.

مثال (45.4-3): min max نفس القيمة المعطيات: نفس M، عمود q باحتمال L. المطلوب: $\min_q \max(M_{:,L}, M_{:,R})$ والتأكّد. الحل: الخطوة 1: $Mq = [2q,\ 1-q]$؛ $\max(2q, 1-q)$؛ أدنى عند $2q = 1-q \Rightarrow q = 1/3 \Rightarrow 1\ldots$ فعلياً $2/3$. النتيجة: $\min\max = 2/3$ (يطابق). الربط بالذكاء الاصطناعي: تساوي min/max.

مثال (45.4-4): وجود سرج نقيّ المعطيات: $M = \begin{bmatrix} 3 & -1 \\ -2 & 4 \end{bmatrix}$. المطلوب: هل يوجد سرج نقيّ؟ الحل: الخطوة 1: $\max\min$ (صفوف): $\min(3,-1) = -1$؛ $\min(-2,4) = -2$؛ $\max = -1$؛ $\min\max$ (أعمدة): $\max(3,-2) = 3$؛ $\max(-1,4) = 4$؛ $\min = 3$. لا تساوٍ نقيّ ($3 \neq -1$). النتيجة: لا سرج نقيّ (لكن مختلط موجود). الربط بالذكاء الاصطناعي: min/max نقيّ يفشل.

مثال (45.4-5): حدّ أدنى مضمون للاعب-1 المعطيات: $M = [[2,0],[0,1]]$، اللاعب-1 يلعب $p = 1/3$.

المطلوب: أقلّ عائد مضمون. الحل: الخطوة 1: $\min(2/3,\ 2/3) = 2/3$ مهما فعل الخصم. النتيجة: $2/3$ مضمون. الربط بالذكاء الاصطناعي: أمان مزيج.

مثال (45.4-6): برمجة خطّية المعطيات: إيجاد v يتطلّب حلّ LP. المطلوب: الشكل. الحل: الخطوة 1: $\max v$ بحيث $p^\top M \geq v\mathbb{1}$، $\sum p = 1, p \geq 0$. النتيجة: LP. الربط بالذكاء الاصطناعي: حلّ فعّال.

مثال (45.4-7): مثال على قيمة سالبة المعطيات: $M = \begin{bmatrix} -1 & -3 \\ -2 & -4 \end{bmatrix}$. المطلوب: v (نقيّ ذرّيّ). الحل: الخطوة 1: $\max\min$: $\min(-1,-3) = -3$؛ $\min(-2,-4) = -4$؛ $\max = -3$؛ $\min\max$: $\max(-1,-2) = -1$؛ $\max(-3,-4) = -3$؛ $\min = -3 \Rightarrow$ تساوٍ. النتيجة: $v = -3$ ($p = U, q = R$ سرج نقيّ). الربط بالذكاء الاصطناعي: خسارة مضمونة.

مثال (45.4-8): قيمة سرج نقيّ أكبر المعطيات: $M = \begin{bmatrix} 4 & 2 \\ 1 & 3 \end{bmatrix}$. المطلوب: التحقّق. الحل: الخطوة 1: $\max\min$: $\min(4,2) = 2$؛ $\min(1,3) = 1$؛ $\max = 2$؛ $\min\max$: $\max(4,1) = 4$؛ $\max(2,3) = 3$؛ $\min = 3 \neq 2 \Rightarrow$ لا سرج نقيّ. النتيجة: v مختلط (لا نقيّ). الربط بالذكاء الاصطناعي: لزوم الاختلاط.

مثال (45.4-9): استراتيجيّة الخصم المعطيات: $M = [[2,0],[0,1]]$، استراتيجيّة العمود. المطلوب: $q^\star$. الحل: الخطوة 1: $q = 1/3$ يمنع أيّ عائد أكبر من $2/3$. النتيجة: $q = 1/3$. الربط بالذكاء الاصطناعي: مقاومة الخصم.

مثال (45.4-10): ألعاب ثنائية في الذكاء الاصطناعي المعطيات: لعبة مثل Go أو الشِّطرنج. المطلوب: ربط بنظرية الصفر. الحل: الخطوة 1: هذه ألعاب ثنائيّة الصفر (فائز واحد)؛ تُحَلّ بالبحث واللعب الذاتيّ. النتيجة: تطبيق مباشر. الربط بالذكاء الاصطناعي: أساس اللعب الذاتيّ.

مثال (45.4-11): تعميم البرمجة الخطّية المعطيات: مصفوفة أكبر $n \times m$. المطلوب: حجم البرنامج الخطّي. الحل: الخطوة 1: المتغيّرات mn (كلّ خانة)؛ والخطّيّة تسمح بحلّ LP فعّال. النتيجة: LP بحجم mn. الربط بالذكاء الاصطناعي: تعقيد حسابيّ مقبول.

مثال (45.4-12): ثنائيّة في الشِّطرنج المعطيات: تعادل الطرفين في لعبة مثل لعبة الحيلة. المطلوب: تقدير قيمة v. الحل: الخطوة 1: بـ$\max\min$ كلّ طرف يضمن حدّاً؛ التساوي يعني التعادل. النتيجة: v تقييم موقف. الربط بالذكاء الاصطناعي: دوال تقييم.

مثال (45.4-13): قطبية LP والثنويّة المعطيات: LP للاعب-1 يوازن LP للاعب-2. المطلوب: العلاقة. الحل: الخطوة 1: ثنويّة LP تجعل $\min\max = \max\min$ (نفس الأمثل). النتيجة: ثنويّة قويّة. الربط بالذكاء الاصطناعي: حلّ بنقطة سرج.

مثال (45.4-14): ثبات LP المعطيات: A_1, A_2 كبار. المطلوب: لماذا نفضّل LP على حصر المصفوفة؟ الحل: الخطوة 1: LP متعدّد الحدود عمليّاً؛ حصر جميع المصفوفات mn مكلف لكنه ما زال LP. النتيجة: LP مفضّل. الربط بالذكاء الاصطناعي: كفاءة.

مثال (45.4-15): خلاصة المعطيات: لعبة ثنائيّة صفر عامّة. المطلوب: ما الذي تضمّنه نظريّة فون-نيومان؟ الحل: الخطوة 1: وجود قيمة v واستراتيجيّات مثلى مضمون (حتى باختلاط). النتيجة: ضمان قيمة. الربط بالذكاء الاصطناعي: أساس نظريّ راسخ.

أخطاء شائعة

- **الخلط بين $\max\min$ و$\min\max$:** يتساويان فقط في الألعاب ثنائيّة الصفر (Thm فون-نيومان).
- **ظنّ وجود سرج نقيّ دائم:** قد لا يوجد؛ يلزم اختلاط.

- **نسيان أن القيمة v للاعب-1 (واللق-الحصيلة سالبة):** منفعة الخصم $= -v$.
- **إهمال محدّبية Δ:** ضروريّة لثنويّة min/max.
- **الخلط بين قيمة اللعبة ونتيجة نقيّة:** قد يلزم مزيج.

صياغة رسمية: يلعب كلّ وكيل أفضل استجابة لتواتر تاريخ الخصم (لعب وهميّ)؛ أو تطوّر الاستراتيجيّات بمنطق المنسوخ:

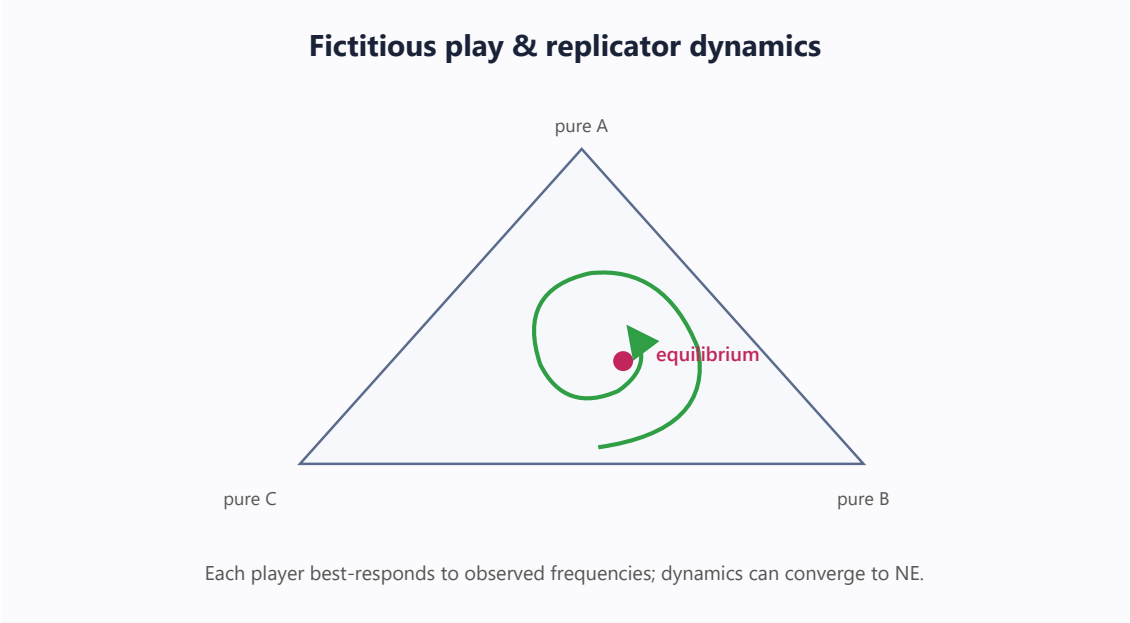
$$\dot{\sigma}_i(a) = \sigma_i(a)\big[u(a,\sigma_{-i}) - \bar{u}_i\big] \qquad \text{منسوخ:} \qquad a_i^{t} = BR_i\Big(\tfrac{1}{t}\sum_{\tau<t} a_{-i}^{\tau}\Big), \qquad \text{وهميّ:} \tag{4.45}$$

جدول الرموز

الرمز	المعنى
BR_i	أفضل استجابة
$\bar{u}_i = \sum_a \sigma_i(a) u(a,\sigma_{-i})$	العائد المتوسّط
$u(a,\sigma_{-i})$	عائد الفعل a مقابل الخصم

الرسم

<figure> الشكل<figcaption> 4.45: تكرار أفضل-الاستجابة قد يقود نقطة اللعب إلى التوازن (ضمن



شكل ٤٠٤٥: *
اللعب الوهميّ

المجْهَز).<figcaption/> </figure>

البرهان

الخطوة 1 (اللعب الوهميّ): كلّ لاعب يلعب BR للتوزيع البعديّ التاريخيّ. ■

الخطوة 2 (المنسوخ): الاستراتيجيّات الأعلى عائداً تنمو بمعدّل يساوي فائضها على المتوسّط. ■

الخطوة 3 (التقارب): في الألعاب ثنائيّة الصفر اللعب الوهميّ يقترب من NE (شابلي 1964)؛ وفي ألعاب الإمكانات المنسوخ يقترب. ■

خمسة عشر مثالاً محلولاً

مثال (5.45-1): أول خطوة وهميّة المعطيات: لاعب-1 لعب U مرّتين، D مرّةً (تواتر $(2/3, 1/3)$). المطلوب: أفضل استجابة إذا كان العائد أعلى في D. الحل: الخطوة 1: العائد المتوقّع لـD مقابل التواتر $\Rightarrow$ يلعب D. النتيجة: D. الربط بالذكاء الاصطناعي: تعلّم من التواتر.

مثال (5.45-2): تحديث منسوخ المعطيات: $\sigma = (0.6, 0.4)$، $u(a) = 3, u(b) = 1$. المطلوب: $\bar{u}$ و$\dot{\sigma}_a$. الحل: الخطوة 1: $\bar{u} = 0.6 \times 3 + 0.4 \times 1 = 1.8 + 0.4 = 2.2$. الخطوة 2: $\dot{\sigma}_a = 0.6(3 - 2.2) = 0.6 \times 0.8 = 0.48 > 0$ (ينمو a). النتيجة: $\dot{\sigma}_a = 0.48$. الربط بالذكاء الاصطناعي: الفعل الأفضل ينمو.

مثال (5.45-3): ثبات عند التوازن المعطيات: $\sigma = (0.5, 0.5)$، $u(a) = u(b) = 2$. المطلوب: $\dot{\sigma}_a$. الحل: الخطوة 1: $\bar{u} = 2$؛ $\dot{\sigma}_a = 0.5(2 - 2) = 0$. النتيجة: 0 (توازن). الربط بالذكاء الاصطناعي: النقطة الساكنة.

مثال (5.45-4): لعب وهميّ في التنسيق المعطيات: لعبة تنسيق، اللاعبان يختاران A تبادليّاً. المطلوب: المسار. الحل: الخطوة 1: كلّ واحد يردّ بـ$A \Rightarrow$ يثبت على توازن التنسيق. النتيجة: يثبت عند A. الربط بالذكاء الاصطناعي: تقارب سريع.

مثال (5.45-5): لعب وهميّ في البنسات المعطيات: مطابقة-معارضة. المطلوب: السلوك. الحل: الخطوة 1: يتبدّلان دوريّاً (تذبذب) حول التوازن المختلط. النتيجة: تذبذب. الربط بالذكاء الاصطناعي: لا تقارب نقيّ.

مثال (5.45-6): متوسط اللعب المعطيات: تواتر $(0.4, 0.6)$. المطلوب: $\bar{u}$ لـ$u = (5, 1)$. الحل: الخطوة 1: $0.4 \times 5 + 0.6 \times 1 = 2 + 0.6 = 2.6$. النتيجة: 2.6. الربط بالذكاء الاصطناعي: عائد تاريخيّ.

مثال (5.45-7): منسوخ ثلاثيّ المعطيات: $\sigma = (0.2, 0.3, 0.5)$، $u = (4, 2, 1)$. المطلوب: $\dot{\sigma}_1$. الحل: الخطوة 1: $\bar{u} = 0.2 \times 4 + 0.3 \times 2 + 0.5 \times 1 = 0.8 + 0.6 + 0.5 = 1.9$. الخطوة 2: $\dot{\sigma}_1 = 0.2(4 - 1.9) = 0.2 \times 2.1 = 0.42$. النتيجة: 0.42 ينمو. الربط بالذكاء الاصطناعي: تهيمن الأفضل.

مثال (5.45-8): أفضل استجابة سريعة المعطيات: تواتر الخصم ثابت. المطلوب: كم خطوة لتثبيت؟ الحل: الخطوة 1: التثبيت فوريّ (لعبة تنسيق)؛ يتأخّر في ألعاب عدديّة. النتيجة: يعتمد على اللعبة. الربط بالذكاء الاصطناعي: سرعة متغيّرة.

مثال (5.45-9): استمراريّة المعطيات: $\sigma \in \Delta$، u مستمرّة. المطلوب: خصائص المنحى. الحل: الخطوة 1: مجال Δ ثابت (حفظ الاحتمالات $\sum \dot{\sigma} = 0$). النتيجة: قياس ثابت. الربط بالذكاء الاصطناعي: ثبات احتماليّ.

مثال (5.45-10): ربط بالإمكان المعطيات: لعبة إمكان Φ. المطلوب: سلوك المنسوخ. الحل: الخطوة 1: Φ يزيد رَتَمّاً (غير متناقص) $\Rightarrow$ تقارب. النتيجة: تقارب مضمون. الربط بالذكاء الاصطناعي: يربط بـ(7.45).

مثال (5.45-11): نقاط ثابتة المنسوخ المعطانات: $\dot{\sigma} = 0 \Rightarrow u(a) = \bar{u}$ لكلّ $\sigma(a) > 0$. المطلوب: العلاقة بـNE. الحل: الخطوة 1: النقاط الثابتة $\subseteq$ توازنات ناش. النتيجة: من subset. الربط بالذكاء الاصطناعي: نظرية التطوّر.

مثال (5.45-12): تقريب اللعب الوهميّ المعطيات: لعبة كبيرة. المطلوب: التعقيد. الحل: الخطوة 1: حفظ تواترات الأكوان $O(\sum \|A_i\|)$ لكلّ خطوة. النتيجة: خطّيّ في الأفعال. الربط بالذكاء الاصطناعي: قابل للتوسّع.

مثال (5.45-13): ديناميكيات غير متقاربة المعطيات: Rock-paper-scissors. المطلوب: سلوك اللعب الوهميّ. الحل: الخطوة 1: يدور حول المركز (لا يتقارب للنقيّ)؛ يقترب من المختلط مع التمهيد). النتيجة: دوران. الربط بالذكاء الاصطناعي: سلوك حلقيّ.

مثال (5.45-14): تأريخ الحدس المعطيات: اللعب الوهميّ ينسى الترتيب (يحتفظ فقط بالتواتر). المطلوب: مكسب/خسارة. الحل: الخطوة 1: بسّط لكنه يفقد معلومة الترتيب الزمنيّ. النتيجة: مقايضة. الربط بالذكاء الاصطناعي:

تصميم.

مثال (15-5.45): خلاصة المعطيات: لعبة ثنائيّة صفر. المطلوب: ما تضمنه اللعب الوهميّ؟ الحل: الخطوة 1: تقارب متوسط التواترات إلى NE (طبقاً لشابلي). النتيجة: تقارب مضمون. الربط بالذكاء الاصطناعي: أمثليّة نظريّة.

أخطاء شائعة

- **الخلط بين اللعب الوهميّ والمنسوخ:** الأوّل أفضل استجابة لتواتر الثانى تطوّر سكّانيّ.
- **نسيان أن الثابت في المنسوخ محذوف:** مجموع المشتقّات صفر (يظلّ $\sigma \in \Delta$).
- **ظنّ التقارب دائماً:** في ألعاب عامّة قد لا يتقاربا.
- **الاعتقاد أنّ نقاط المنسوخ الثابتة = NE جمع:** هي فقط ضمن NE.
- **الخلط بين التواتر والمعاملات:** التردّد ليس ستراتيجيّة ذات وزن (unweighted).

صياغة رسمية: ندامة الفعل a حتى الزمن T (بصياغة الفوز):

$$R^T(a) = \sum_{t=1}^{T} \big(g^t(a) - g^t(a^t) \big), \qquad R^T_{\max} = \max_a R^T(a) \tag{5.45}$$

وخوارزميّة Hedge (التحديث الأوّليّ الضاربّة):

$$w_{t+1}(a) = w_t(a)\, e^{-\eta \mu^t(a)}, \qquad \sigma_t(a) = \frac{w_t(a)}{\sum_{a'} w_t(a')} \tag{6.45}$$

وتقويض متوسط الاستراتيجيّة هو توازن ε-ناشيّ بـ$\varepsilon = R^T_{\max}/T$.

جدول الرموز

الرمز	المعنى
$g^t(a)$	فوز الفعل a في الجولة t
R	ندامة تراكميّة
CFR	تقليف الندامة المضادّ
$\bar{\sigma}$	متوسط الاستراتيجيّة

الرسم

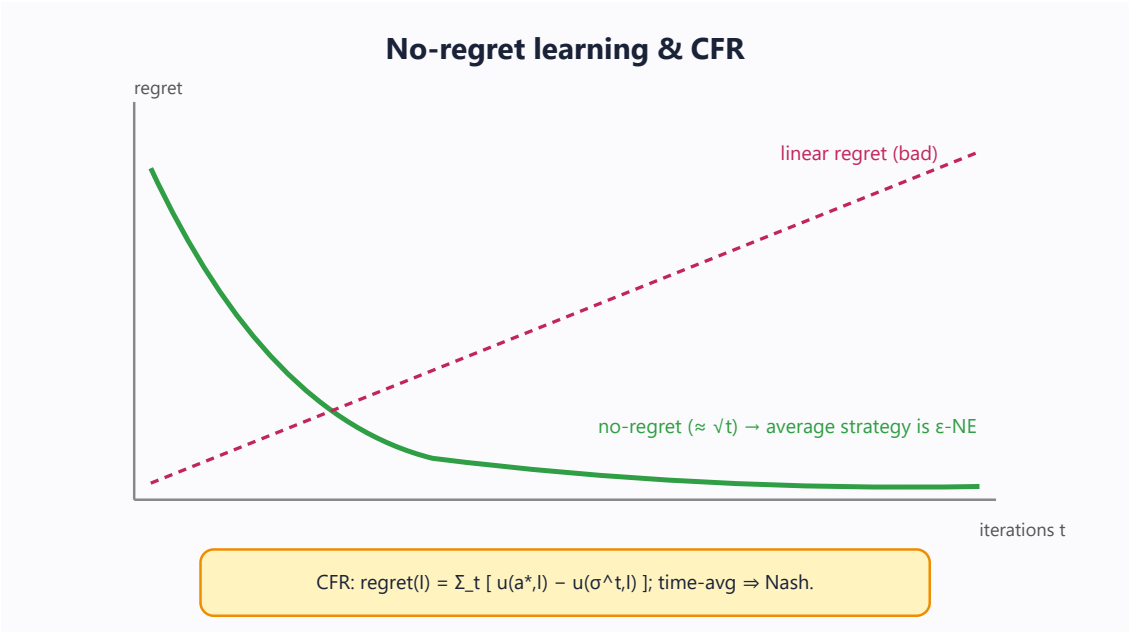
<figure> الشكل<figcaption> 5.45: الندامة تنمو دون خطّي $(\sqrt{t})$؛ متوسط الاستراتيجيّة يقترب من توازن ناشيّ.</figcaption> </figure>

البرهان

الخطوة 1 (حدّ N•و): Hedge يحقّق $\max_a R^T(a) = O(\sqrt{T \ln K})$ لكلّ لاعب. ■

الخطوة 2 (من الندامة للتوازن): σ^T متوسط يحقّق استجابة أساسيّة؛ تقليل الحدّ الأقصى للندامة $\Rightarrow$ ε-NE مع $\varepsilon = R^T_{\max}/T$. ■

الخطوة 3 (CFR العمليّة): في العقدة-المعلومات I، الندامة المضادّ تقيس: "لو لعبتُ بديلاً"؟ منسوباً بالاحتمالات π؛ ومطابَقة الندامة تُحدّث الاستراتيجيّة. ■



شكل ٥.٤٥: *
CFR والندامة

خمسة عشر مثالاً محلولاً

مثال (1-6.45): ندامة فعل المعطيات: لعبناه a_1 أبداً،$g(a_1) = 0.5$،أفضل $g(a_2) = 0.8$،$T = 100$. المطلوب: $R^{100}(a_2)$. الحل: الخطوة 1: $100 \times (0.8 - 0.5) = 30$. النتيجة: 30. الربط بالذكاء الاصطناعي: خسارة 3.0 لكلّ خطوة.

مثال (2-6.45): ε-NE المعطيات: $R_{\max} = 10$،$T = 1000$. المطلوب: ε. الحل: الخطوة 1: $\varepsilon = R_{\max}/T = 10/1000 = 0.01$. النتيجة: $\varepsilon = 0.01$-NE. الربط بالذكاء الاصطناعي: توازن تقريبيّ.

مثال (3-6.45): Hedge بثوابت المعطيات: $\mu = (1, 2, 3)$،$\eta = 0.5$. المطلوب: σ. الحل: الخطوة 1: أوزان $(e^{-0.5}, e^{-1}, e^{-1.5}) = (0.607, 0.368, 0.223)$؛ المجموع 1.198. الخطوة 2: $\sigma = (0.506, 0.307, 0.187)$. النتيجة: $\sigma = (0.51, 0.31, 0.19)$. الربط بالذكاء الاصطناعي: وزن أكبر للأرخص.

مثال (4-6.45): $\eta = 1$ المعطيات: نفس μ،$\eta = 1$. المطلوب: σ. الحل: الخطوة 1: أوزان $(0.368, 0.135, 0.050)$؛ مجموع 0.553؛ $\sigma = (0.665, 0.244, 0.090)$. النتيجة: أقرب للأوّل. الربط بالذكاء الاصطناعي: η أصغر يُسنّد للرخيص.

مثال (5-6.45): ربط بين η والمعدّل (US) المعطيات: $\eta = \sqrt{8 \ln K / T}$. المطلوب: معنى. الحل: الخطوة 1: يتناقص مع T؛ يوازن بين التعلّم والثبات. النتيجة: معايرة نظريّة. الربط بالذكاء الاصطناعي: حدود.

مثال (6-6.45): تطبيق Hedge المعطيات: ثلاثة خبراء بتكلفات. المطلوب: الاختيار. الحل: الخطوة 1: نختار استراتيجيّاً بوزن عكسيّ لخسائرهم التاريخيّة. النتيجة: اختيار موزون. الربط بالذكاء الاصطناعي: مشكلة الخبراء.

مثال (7-6.45): CFR لتحديث الندامة المعطيات: ندامة $R = 0.2 > 0$ لكشف فعل في عقدة. المطلوب: σ الجديد. الحل: الخطوة 1: $\sigma(a_{\text{ندم}}) + = 0.2$ (إعادة تطبيع). النتيجة: رفع احتمال الفعل الندمين. الربط بالذكاء الاصطناعي: قاعد تصحيح.

مثال (8-6.45): افعال عدد كبير (K big) المعطيات: $K = 1000$،$T = 10^4$،$\ln K \approx 6.9$. المطلوب: مرتبة الندامة. الحل: الخطوة 1: $\sqrt{10^4 \times 6.9} = \sqrt{69000} \approx 263$؛ $O(\sqrt{T \ln K}) = 0.026$؛ $\varepsilon = 263/10^4 = 0.026$. النتيجة: $\varepsilon \approx 0.026$. الربط بالذكاء الاصطناعي: نماذج كبيرة تتباين.

مثال (45.6-9): تقارب العدد المعطيات: T تتضاعف. المطلوب: سلوك ε. الحل: الخطوة 1: $\varepsilon \propto \sqrt{\ln K/T}$ ينقص. النتيجة: يصغر بمعدّل $1/\sqrt{T}$. الربط بالذكاء الاصطناعي: ضمان خلوص.

مثال (45.6-10): ندامة سالبة (غير ممكن) المعطيات: $R(a) \geq 0$ دائماً باختلاف $a^t \in A$. المطلوب: التحقّق. الحل: الخطوة 1: كلّ $R^t(a^t) = 0$ (الفرع نفسه)، الآخرون ≥ 0. النتيجة: $R \geq 0$. الربط بالذكاء الاصطناعي: سلامة القياس.

مثال (45.6-11): CFR في Poker المعطيات: لعبة واسعة مثل البوكر. المطلوب: لماذا يعمل CFR؟ الحل: الخطوة 1: يعالج كلّ عقدة-معلومات على حدة باستعمال الندامة المضادّ. النتيجة: يتناسب مع كلّ عقدة-معلومات. الربط بالذكاء الاصطناعي: CFR ،ingames.

مثال (45.6-12): هكرا على تطبيق (زسيّ) المعطيات: عدد info-set ضخم. المطلوب: المشكلة العمليّة. الحل: الخطوة 1: حجم اللعبة أُسّيّ $\Rightarrow$ تحتاج تعميماً بالشبكات. النتيجة: تعميم بالشبكات. الربط بالذكاء الاصطناعي: Deep CFR.

مثال (45.6-13): استراتيجيّة متوسّطة المعطيات: $\bar{\sigma}^T = \frac{1}{T}\sum_t \sigma^t$. المطلوب: لماذا المتوسّط وليس الأخير؟ الحل: الخطوة 1: الأخير قد يتذبذب، المتوسّط يحقّق ε-NE. النتيجة: المتوسّط مضمون. الربط بالذكاء الاصطناعي: ثبات.

مثال (45.6-14): نظرية ناش قابلة للحساب المعطيات: لا نهائيّة. المطلوب: النتيجة. الحل: الخطوة 1: متوسط الاستراتيجيّة يتقارب إلى ε. النتيجة: خوار متقاربة. الربط بالذكاء الاصطناعي: تقارب تقريبيّ

مثال (45.6-15): خلاصة المعطيات: $R^T_{\max} = O(\sqrt{T \ln K})$. المطلوب: ناتج ε-NE. الحل: الخطوة 1: $\varepsilon = O(\sqrt{\ln K/T})$ يتلاشى مع T. النتيجة: تقارب إلى Nash. الربط بالذكاء الاصطناعي: قاعدة نظرية للتعلّم الاستراتيجيّ.

أخطاء شائعة

- **الخلط بين المكسبة والخسارة:** ندامة التكلفة تُطرح، في الفوز تُجمع.
- **نسيان أن التوازن تقديري (ε):** متوسط Hedge هو ε-NE لا Nash تامّ.
- **الظنّ أن CFR يحلّ كلّ لعبة:** يتقارب نحو توازناً ناشيّاً تامّاً دقيقاً.
- **إهمال تطبيع الاستراتيجيّة:** الاحتمالات يجب أن تُجمع 1.
- **الخلط بين الندامة والعودة:** العودة تحتاج تقارن مع أفضل ثابت، لكنها أقلّ صلابة.

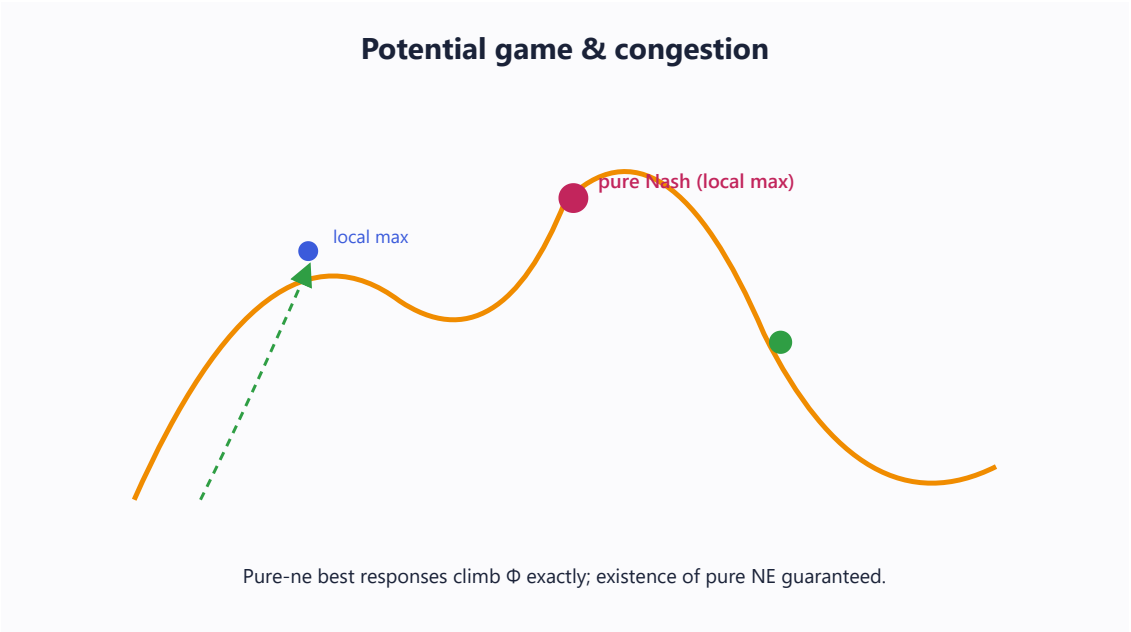
صياغة رسمية: اللعبة لعبة إمكان إذا وُجدت دالّة $\Phi : A \to \mathbb{R}$ بحيث:

$$u_i(a'_i, a_{-i}) - u_i(a_i) = \Phi(a'_i, a_{-i}) - \Phi(a_i, a_{-i}) \qquad \forall i,\ \forall a_i, a'_i \tag{7.45}$$

وفي ألعاب الازدحام تُحسب الإمكان بالمجموع على المصادر: $\Phi(\mathbf{a}) = \sum_r f_r(n_r(\mathbf{a}))$.

جدول الرموز

الرمز	المعنى
Φ	دالّة الإمكان
n_r	عدد اللاعبين على المصدر r
f_r	كلفة المصدر r



شكل ٦.٤٥: *
لعبة إمكان

الرسم

<figure> الشكل<figcaption> 6.45: أفضل-الاستجابة يصعد على Φ؛ القمم المحليّة توازنات ناشٍ نقيّة.</figcaption>
</figure>

البرهان

الخطوة 1 (التعريف): Φ يوحّد دوالّ المنافع: تحسّن أحد مرتبط بتحسّن Φ بذات المقدار. ■

الخطوة 2 (تصاعد): أيّ انحراف مفضّل يرفع Φ بكمٍّ موجب. ■

الخطوة 3 (النهاية): اللعبة منتهية وΦ منتهيّة $\Rightarrow$ الوصول إلى قمّة محلّية = توازن ناشٍ نقيّ. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.45): إمكان لعبة توافق المعطيات: لعبة 2×2 بتناسق حيث $(A,A) = (1,1)$، $(B,B) = (2,2)$، غير متناسق $(0,0)$. المطلوب: Φ. الحل: الخطوة 1: $\Phi = A,A$ ؛ الخطوة 2: $\Phi = B,B$ ؛ Φ المختلطة 0 (يجمع العائدين). النتيجة: Φ = مجموع العائدين. الربط بالذكاء الاصطناعي: توافق كامل الأهل.

مثال (2-7.45): توازن نقيّ المعطيات: من (1-7.45). المطلوب: توازنات ناشٍ نقيّة. الحل: الخطوة 1: (A,A) توازن (لا يحسّن أحد بالانحراف) و(B,B) توازن. النتيجة: توازنان نقيّان. الربط بالذكاء الاصطناعي: اصطفاء مطلوب.

مثال (3-7.45): الازدحام المتناسق المعطيات: 2 طريقة متطابقتان، كلفة كلّ سائق = عدد السواقة على طريقه؛ سائقان. المطلوب: جميع الحالات. الحل: الخطوة 1: $(2,0)$: كلّ سائق كلفة 2، مجموع 4. $(1,1)$: كلّ سائق كلفة 1، مجموع 2. النتيجة: $(1,1)$ كلفة أقلّ. الربط بالذكاء الاصطناعي: سعر الفوضى.

مثال (4-7.45): NE في الازدحام المعطيات: $(1,1)$ (من 3-7.45). المطلوب: هل هي توازن؟ الحل: الخطوة 1: سائق ينتقل للطريق الآخر يصير $(0,2)$، كلفته 2 (أسوأ) $\Rightarrow$ لا ينتقل. النتيجة: $(1,1)$ توازن نقيّ. الربط بالذكاء الاصطناعي: تناسق مستقرّ.

مثال (45.7-5): أربعة سوّاقين المعطيات: 4 سوّاقين، طريقتان. المطلوب: NE. الحل: الخطوة 1: $(2,2)$؛ أيّ انفراد $\Rightarrow (3,1)$؛ كلفة المنتقل 2<3 $\Rightarrow$ مستقرّ. النتيجة: $(2,2)$ توازن. الربط بالذكاء الاصطناعي: توازن متوازن.

مثال (45.7-6): مجموع الكلفة عند التوازن المعطيات: $(2,2)$ من (45.7-5). المطلوب: الكلفة الاجتماعيّة. الحل: الخطوة 1: كلّ سائق كلفة $2 \Rightarrow 2 \times 4 = 8$. النتيجة: 8. الربط بالذكاء الاصطناعي: كفاءة هنا مثاليّة.

مثال (45.7-7): مثال بيجو المعطيات: طريقتان: الأولى كلفة ثابتة 1؛ الثانية $x^2/200$ =؛ 100 سائق، x على الثانية. المطلوب: الكلفة الاجتماعيّة للثانية. الحل: الخطوة 1: الكلفة الاجتماعيّة $x^3/200 + (100 - x)$ =؛ بأخذ المشتقة $3x^2/200 - 1 = 0 \Rightarrow x = \sqrt{200/3} \approx 8.16$. النتيجة: التوازن دون الاجتماعيّ. الربط بالذكاء الاصطناعي: سعر الفوضى < 1.

مثال (45.7-8): ثمن الفوضى المعطيات: كلفة اجتماعيّة مثليّة 0.5؛ عند التوازن 1.0 (مثال مبسّط). المطلوب: النسبة. الحل: الخطوة 1: $1.0/0.5 = 2$. النتيجة: مرّتين. الربط بالذكاء الاصطناعي: كفاءة التوازن.

مثال (45.7-9): إمكان دقيق مقابل رتبي المعطيات: إمكان دقيق يعبر بفروق متساويّة. المطلوب: الفرق. الحل: الخطوة 1: الرتبي يكفي لضمان وجود NE لكن ليس لتقارب كلّ الديناميات. النتيجة: دقيق أقوى. الربط بالذكاء الاصطناعي: تطوّر التسميات.

مثال (45.7-10): ألعاب الازدحام لها NE نقيّ المعطيات: Φ من دالّة كلفات. المطلوب: المضمون. الحل: الخطوة 1: كلّ لعبة ازدحام لعبة إمكان $\Rightarrow$ NE نقيّ موجود. النتيجة: مضمون. الربط بالذكاء الاصطناعي: نتيجة روزنتال.

مثال (45.7-11): إمكان عامّة المعطيات: مصدران بكمّيتين مختلفتي الكلفة. المطلوب: Φ. الحل: الخطوة 1: $\Phi = f_1(n_1) + f_2(n_2)$ (منفصل عن التبديل). النتيجة: مجموع كلفات المصادر. الربط بالذكاء الاصطناعي: تلخيص.

مثال (45.7-12): كلفة رتبيّة المعطيات: $f_r(n) = e^n$. المطلوب: الكلفة على مصدر بـ$n = 3$. الحل: الخطوة 1: $e^3 \approx 20.09$. النتيجة: 20.09. الربط بالذكاء الاصطناعي: كلفة أُسّيّة مع الازدحام.

مثال (45.7-13): مقارنة بين مصدرين المعطيات: $f_1(n) = n$، $f_2(n) = 0.5n^2$؛ $n_1 = 2, n_2 = 2$. المطلوب: Φ. الحل: الخطوة 1: $2 + 0.5 \times 4 = 2 + 2 = 4$. النتيجة: 4. الربط بالذكاء الاصطناعي: تقييم هندسيّ.

مثال (45.7-14): أفضل استجابة يصعد المعطيات: إعادة توزيع تُخفض كلفة سائق. المطلوب: علاقة Φ. الحل: الخطوة 1: انحرافه يخفض كلفته $\Rightarrow$ يخفض كلفة الجميع على المصدرين $\Rightarrow$ يخفض Φ (هبوط نحو التوازن). النتيجة: Φ تنقص. الربط بالذكاء الاصطناعي: هبوط نحو التوازن.

مثال (45.7-15): خلاصة المعطيات: أيّ لعبة ازدحام. المطلوب: المضمون. الحل: الخطوة 1: وجود توازن ناشٍ نقيّ عبر دالّ إمكان. النتيجة: NE نقيّ مضمون. الربط بالذكاء الاصطناعي: نتائج قويّة.

أخطاء شائعة

- **الخلط بين الإمكان الرتبي والدقيق:** الرتبي يكفي للوجود لا للتقارب.
- **الخلط بين سعر الفوضى والكلفة الاجتماعيّة:** مرتبطان لكن سعر الفوضى نسبة بين اللّاء.
- **نسيان أن NE نقيّاً ليس بالضرورة الأمثل اجتماعيّاً:** كثيراً ما يفوق.
- **الظنّ أن كلّ لعبة لإبة:** كثير من الألعاب ليست ذوات إمكان.
- **إهمال اتجاه صعود Φ:** أفضل-الاستجابة يقلّل الكلفة (للازدحام) $\Rightarrow$ هبوط.

صياغة رسمية: عند وجود عدّة وكلاء، كلّ وكيل i يعظّم عائده الخاصّ بينما يتعلّم الآخرون:

$$\pi_i^\star = \arg\max_{\pi_i} \mathbb{E}\big[\sum_t \gamma^t r_i^t\big] \quad \text{معتبراً الخصوم جزءاً من البيئة} \tag{8.45}$$

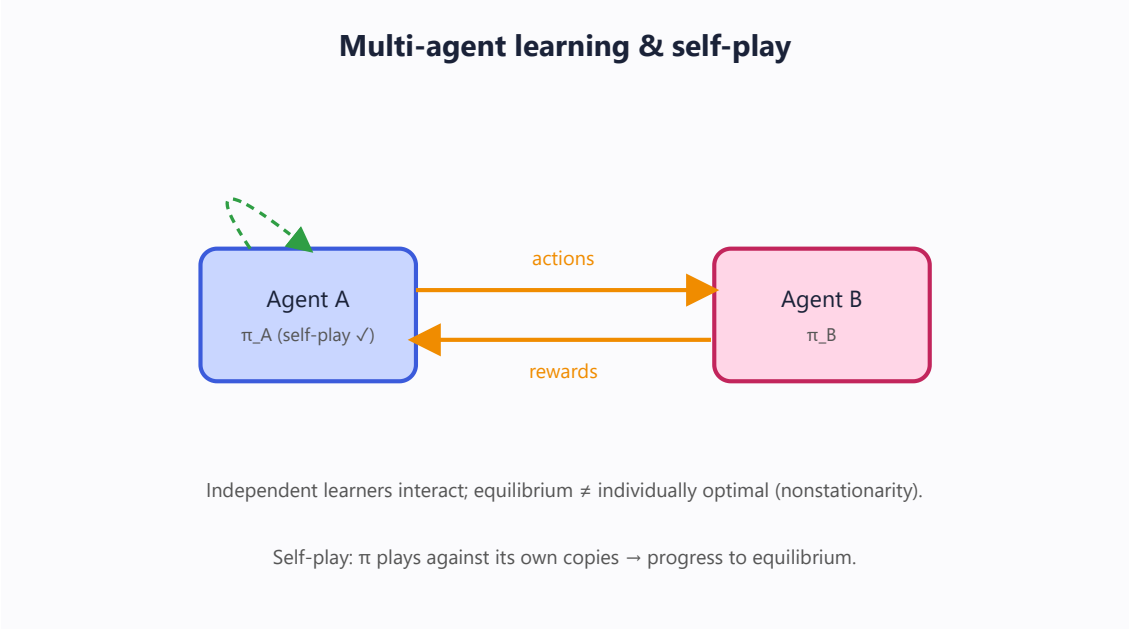
لكنّ حضور وكلاء متعلّمين يجعل البيئة غير ثابتة؛ والهدف ليس عائداً أمثليّاً بل توازناً ناشيّاً؛ واللعب الذاتيّ يصنع منهجاً تعليميّاً متزايد الصعوبة.

جدول الرموز

الرمز	المعنى
π_{-i}	سياسات الآخرين (البيئة غير الثابتة)
Elo	تقييم نسبيّ للاعبين
السياسة المشتركة	تعظيم مجموع العوائد للفريق
assignment credit	عَزو المكافأة للوكيل المسؤول

الرسم

<figure> الشكل<figcaption> 7.45: وَكيلان يتعلّمان معاً؛ اللعب الذاتيّ يجعل كلّ نسخة خصماً للنسخة



شكل ٧.٤٥: *
تعلّم متعدّد الوكلاء

السابقة.</figcaption> </figure>

البرهان

الخطوة 1 (عدم الثبات): من منظور وكيل، π_{-i} متغيّر (يتعلّم) $\Rightarrow$ بيئة غير ماركوفيّة. ■

الخطوة 2 (فضاء مشترك): العائد عند التوازن ليس $\max_i \sum r_i$ بل نقطة ناش؛ حجم الفعل المشترك $\prod_i \|A_i\|$ ينمو أُسّيّاً. ■

الخطوة 3 (اللعب الذاتيّ): اللعبة ضدّ نسخة نفسك يُولّد خصوماً بأداء مماثل $\Rightarrow$ منهج تدرّجيّ يقترب من توازن. ■

خمسة عشر مثالاً محلولاً

مثال (45.8-1): سطح غير ثابت المعطيات: وَكيلان يلعبان مطابقة بنسات، كلٌّ يتعلّم استجابةً. المطلوب: لماذا يفشل التعلّم المفرد؟ الحل: الخطوة 1: مواجهة خصم متعلّم = بيئة متغيّرة ⇒ التوزيع المستهدف يتبدّل. النتيجة: عدم ثبات. الربط بالذكاء الاصطناعي: يكسر خاصيّة ماركوف.

مثال (45.8-2): Q مستقلّ المعطيات: وَكيلان يخزّنان Q_1, Q_2 مستقلّتين. المطلوب: نوع الخوارزم. الحل: الخطوة 1: تعلّم Q مستقلّ ؛(IQL) كلّ واحد يعتبر الآخر بيئة عشوائيّة. النتيجة: IQL. الربط بالذكاء الاصطناعي: أبسط MARL.

مثال (45.8-3): عائد التوازن المعطيات: لعبة (2,3)=(D,R) (من 45.2). المطلوب: هل الجميع يزيد؟ الحل: الخطوة 1: لا؛ التوازن يقفل العائدات عند (2,3) وليس أعلى للأثنين. النتيجة: مقيّد بالتوازن. الربط بالذكاء الاصطناعي: توازن ليس أمثل اجتماعياً.

مثال (45.8-4): حجم الفعل المشترك المعطيات: 10 وكلاء × 4 أفعال. المطلوب: عدد الأكوان المشتركة. الحل: الخطوة 1: $4^{10} \approx 1.05 \times 10^6$. النتيجة: 10^6 نحو مليون. الربط بالذكاء الاصطناعي: لعنة الأُسّ.

مثال (45.8-5): تخصيص الفضل المعطيات: فريق روبوتات يرفع صندوقاً، جماعي +1. المطلوب: المشكلة. الحل: الخطوة 1: كلّ روبوت يريد جزء الفضل (credit) لا مكافأة الفريق. النتيجة: تحدٍّ في تخصيص الفضل. الربط بالذكاء الاصطناعي: تحدٍّ جوهريّ.

مثال (45.8-6): Elo لفوز المعطيات: تقييم 2400 مقابل 2000. المطلوب: النتيجة المُتوقّعة. الحل: الخطوة 1: $1/(1 + 10^{(2000-2400)/400}) = 1/(1 + 10^{-1}) = 1/1.1 \approx 0.909$. النتيجة: 0.909. الربط بالذكاء الاصطناعي: توقّع فوز قويّ.

مثال (45.8-7): Elo متساوٍ المعطيات: تقييمان متساويان. المطلوب: النتيجة. الحل: الخطوة 1: $1/(1 + 10^0) = 0.5$. النتيجة: 0.5. الربط بالذكاء الاصطناعي: مناصفة.

مثال (45.8-8): الأضعف يُفاجأ المعطيات: تقييم 1600 مقابل 2000. المطلوب: النتيجة المتوقّعة للأضعف. الحل: الخطوة 1: $1/(1 + 10^{(2000-1600)/400}) = 1/(1 + 10) = 1/11 \approx 0.091$. النتيجة: 0.091. الربط بالذكاء الاصطناعي: ضعيف بشكل متوقّع.

مثال (45.8-9): لعب ذاتي تدريجيّ المعطيات: نموذج يهزم نسخته السابقة repeatedly. المطلوب: السلوك. الحل: الخطوة 1: الأداء يصعد تصاعيداً حتّى يتباطأ أو يستقرّ. النتيجة: تطوّر تدريجيّ. الربط بالذكاء الاصطناعي: منهج ذاتي.

مثال (45.8-10): توازن اللعب الذاتي (fictitious) المعطيات: نسخة اللعب الذاتي = لعب وهمي ضدّ التاريخ. المطلوب: العلاقة بالتوازن. الحل: الخطوة 1: يتقارب إلى توازن ناش متوسط. النتيجة: نحو Nash. الربط بالذكاء الاصطناعي: ربط بـ45.5.

مثال (45.8-11): توازن اللعب الذاتي (وهميّ) المعطيات: نسخة اللعب الذاتي تُعامَل كلعب وهميّ ضدّ التاريخ. المطلوب: العلاقة بالتوازن. الحل: الخطوة 1: يتقارب متوسط الاستراتيجيّة إلى توازن ناشٍ تقريبيّ. النتيجة: نحو Nash. الربط بالذكاء الاصطناعي: ربط بـ(45.5).

مثال (45.8-12): إعادة استخدام العيّنات المعطيات: وَكيلان يتعلّمان من تجارب مشتركة. المطلوب: فائدة. الحل: الخطوة 1: تجارب كلّ وكيل تُعلّم الآخر (بيانات أكثر للجميع). النتيجة: عيّنات مشتركة. الربط بالذكاء الاصطناعي: كفاءة.

مثال (45.8-13): انعدام التوازن المعطيات: كلا الوَكيلين يستعمل استراتيجيّتين. المطلوب: هل التقاطع سهل؟ الحل: الخطوة 1: قد يكون متعدّداً؛ الاصطفاء يحتاج ديناميكيّ لا تثبيتاً. النتيجة: اصطفاء مطلوب. الربط بالذكاء الاصطناعي:

اختيار التوازن.

مثال (14-8.45): تحويل القوة المعطيات: نسخة جديدة من نموذج قويّ. المطلوب: ضرورة. الحل: الخطوة 1: نسخة قديمة خصم ضعيف $\Rightarrow$ لا تعلّم جديد؛ يلزم تحديث. النتيجة: تحديث دوريّ. الربط بالذكاء الاصطناعي: ضدّ الانهيار.

مثال (15-8.45): خلاصة المعطيات: n وَكيل متعلّم. المطلوب: الهدف الصحيح. الحل: الخطوة 1: التقرّب من توازن ناشٍ (ضمنيّاً) لا تعظيم عائد مفرد. النتيجة: توازن. الربط بالذكاء الاصطناعي: قلب MARL.

أخطاء شائعة

- **افتراض ثبات البيئة:** مع وَكيلين متعلّمين البيئة غير ماركوفيّة.
- **الخلط بين العائد المفرد والتوازن:** الهدف توازن ناش لا أمثل جمعيّ بالضرورة.
- **نسيان لعنة الأُسّ في الفعل المشترك.**
- **تجاهل تخصيص الفضل:** مكافأة الفريق لا تُبيّن دور كلّ وكيل.
- **الاعتماد على خصم ثابت في اللعب الذاتيّ:** يلزم تحديث النسخ.

جدول تجميع النظريات

النظرية	العنوان	المعادلة المحوريّة	الرسم
2.45	الصياغة العادية وNash	لا انفراد يحسّن	fig-4501
3.45	وجود Nash	توازن مُخالط مضمون	fig-4502
4.45	ثنائيّة الصفر والحدّ	$\max\min = \min\max = v$	fig-4503
5.45	ديناميكيات التعلّم	اللعب الوهميّ/المنسوخ	fig-4504
6.45	الندامة وCFR	متوسط Hedge هو ε-NE	fig-4505
7.45	ألعاب الإمكانات	u-فرق $=$ Φ-فرق $\Rightarrow$ NE نقيّ	fig-4506
8.45	متعدّد الوكلاء	MARL واللعب الذاتيّ	fig-4507

عشرون تمريناً محلولاً (إجابات موجزة)

١. **(Nash)** مصفوفة الشكل 1.45 — (D, R).

٢. **(أفضل استجابة)** صفّ مقابل L (شكل 1.45) — U.

٣. **(Nash مفرد السجن)** — $(D, D) = (1, 1)$.

٤. **(اجتماعيّ vs Nash)** مجموع (D, D) — (C, C) — $6 - 2 = 4$.

٥. **(بلا Nash نقيّ)** مطابقة بنسات — لا يوجد.

٦. **(Nash مُخالط)** توازن المطابقة-المعارضة — $(0.5, 0.5)$؛ $v = 0$.

٧. **(وصول)** قيم $M = [[2, 0], [0, 1]]$ — $v = 2/3$.

٨. **(min max)** نفس M من التمرين 7 — $2/3$ كذلك.

٩. **(لا سرج نقيّ)** $M = [[3, -1], [-2, 4]]$ — $\max\min = -1 \neq \min\max = 3$.

١٠. **(منسوخ)** $\sigma = (0.6, 0.4)$، $u = (3, 1) - \dot{\sigma} = 0.48$.

١١. **(منسوخ ثابت)** $u = u_{\text{متوسط}} - \dot{\sigma} = 0$.

١٢. **(ندامة)** غلطة 0.3 على $T = 100 - 30$.

١٣. **(NE-ε)** $R_{\max} = 10, T = 1000 - 0.01$.

١٤. **(Hedge)** $\eta = 0.5 - \mu = (1, 2, 3) - \sigma \approx (0.51, 0.31, 0.19)$.

١٥. **(Hedge $\eta = 1$)** $- \sigma \approx (0.66, 0.24, 0.09)$.

١٦. **(إمكان ازدحام)** سائقان بطريقتين — توازن $(1, 1)$؛ كلفة 2.

١٧. **(كلفة التوازن)** $(2, 2)$ بسائقين أربعة — 8.

١٨. **(Elo)** 2400 مقابل 2000 — 0.909.

١٩. **(Elo متساوٍ)** — 0.5.

٢٠. **(فعل مشترك)** 10 وكلاء × 4 أفعال — $\approx 10^6$.

فهرس الرموز

الرمز	المعنى	أول ورود
u_i	منفعة اللاعب	1.45
σ_i	استراتيجيّة مُخالطة	2.45
BR_i	أفضل استجابة	2.45
v	قيمة لعبة صفر	4.45
$R^T(a)$	ندامة الفعل	6.45
Φ	دالّة الإمكان	7.45
$\bar{\sigma}$	متوسط الاستراتيجيّة	6.45

المراجع

- Nash, J. (1950). *Games N-person in Points Equilibrium*. PNAS.
- Neumann, von J., Morgenstern, O. (1944). *Theory of Games and Economic Behavior*. Princeton.
- Brown, G. (1951). *Iterative Solution of Games by Fictitious Play*. Naval Research Logistics.
- Zinkevich, M. et al. (2007). *Regret Minimization in Games with Incomplete Information*. NeurIPS.
- Rosenthal, R. (1973). *A Class of Games Possessing Pure-Strategy Nash Equilibria*. IJGT.
- Silver, D. et al. (2016). *Mastering the Game of Go with Deep Neural Networks and Tree Search*. Nature; AlphaGo Zero (self-play example).

الطوبولوجيا وتحليل البيانات الطوبولوجي (TDA)

«الشكل أعظم من أن يُختزل في مسافة واحدة؛ فالبيانات تحمل ثقوباً وحلقات تروي قصّتها الطوبولوجية.»

تتجاهل الطرق الإحصائيّة شكل البيانات العالميّ: هل هي موصولة؟ كم حلقةً تحمل؟ هل تحمل الفراغات بنية؟ تحليل البيانات الطوبولوجيّ (TDA) يُجيب عبر التجانس والتجانس الدائم، ويمنح وصفاً رياضيّاً دقيقاً لا يتوقّف على اختيار المسافة أو الإحداثيات.
سبع نظريات:

- **2.46 المُعقّدات السطحية والمشغّل الحدّي** — $\partial^2 = 0$.
- **3.46 التجانس وأرقام بيتيّ** — $H_k = Z_k/B_k$، $\beta_k = \dim H_k$.
- **4.46 التجانس الدائم** — filtrations وبطاقات الاستمرار.
- **5.46 نظريّة ثبات التجانس الدائم** — $W_\infty(\mathrm{PD}(f),\mathrm{PD}(g)) \le \|f-g\|_\infty$.
- **6.46 تجميعات ڤيتوريس-ريبس وČech** — بناء مُعقّد من سحابة نقاط.
- **7.46 المخطّطات (Mapper)** — تعميم التجميع يحفظ الشكل.
- **8.46 تطبيقات TDA في التعلّم** — ميزات استمرارية للمصنّفات.

كلّ نظرية تتبع القالب: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
K	مُعقّد سطحيّ	مجموعة من المُبسّطات
∂_k	مشغّل الحدّ	$\partial_{k-1}\partial_k = 0$
H_k	جماعة التجانس للأبعاد k	Z_k/B_k
β_k	رقم بيتيّ	$\dim H_k$
PD	مخطط الاستمرار	barcode
ε	مقياس المُرشِّح	يُحدّد التجميع

الاتفاقيات: $\sigma = [v_0,\dots,v_k]$ مُبسّط؛ العمليات على السلاسل الخطّيّة $\sum a_i\sigma_i$. كلّ المعادلات في كتل LTR.

صياغة رسمية: المُبسّط k-الأبعاد $\sigma = [v_0,\dots,v_k]$ (مُحدَّب لـ $k+1$ نقطة مستقلّة)؛ والمُعقّد السطحيّ K مجموعة مُبسّطات مغلقة على الوجوه والتقاطعات؛ والمشغّل الحدّي:

$$\partial_k[v_0,v_1,\dots,v_k] = \sum_{i=0}^{k} (-1)^i [v_0,\dots,\hat{v}_i,\dots,v_k] \tag{1.46}$$

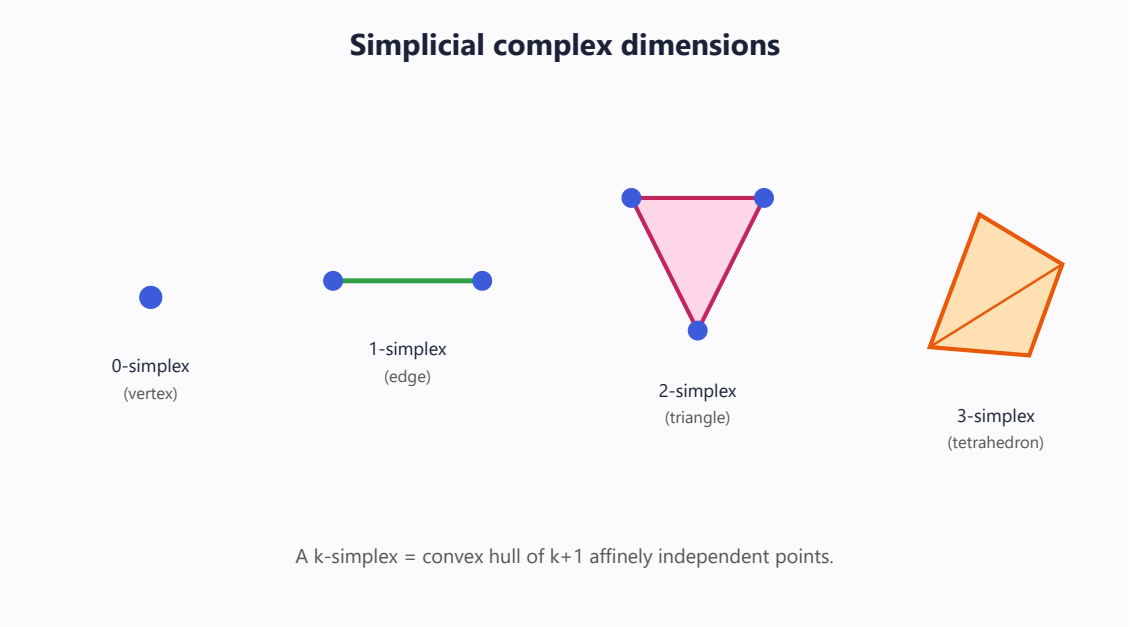
حيث $\hat{v}_i$ تعني حذف v_i.

جدول الرموز

الرمز	المعنى
σ	مُبسّط
C_k	مجموعة سلاسل الأبعاد k (توليدها على حقل)
$\partial^2 = 0$	حدود الحدود معدومة

الرسم

<figure> الشكل<figcaption> 1.46: المُبسّطات بأبعادها: نقطة (0)، حافة (1)، مثلّث (2)، رباعيّ سطحيّ



شكل ١.٤٦: *
المُبسّطات

(3).</figcaption> </figure>

البرهان

الخطوة 1 (تعريف المبسّط والمُعقّد): المُبسّط أصغر قطعة واحدة (مثلّث أو حافة)؛ والمُعقّد يلصقها حسب قواعد مغلقة. ■

الخطوة 2 (التطبيع): ∂ خطّيّ؛ يُمدّ على السلاسل بالخطّيّة. ■

الخطوة 3 (النظريّة الأساس): $\partial_{k-1}(\partial_k \sigma) = 0$ لأنّ كلّ $(k-2)$-وجه يظهر مرّتين بإشارتين متعاكستين تلغيانه. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.46): حدّ حافة المعطيات: $\sigma = [v_0, v_1]$. المطلوب: $\partial_1 \sigma$. الحل: الخطوة 1: $\partial[v_0, v_1] = [v_1] - [v_0]$. النتيجة: $v_1 - v_0$. الربط بالذكاء الاصطناعي: طرفا الحافة.

مثال (2-2.46): حدّ مثلّث المعطيات: $\sigma = [v_0, v_1, v_2]$. المطلوب: $\partial_2 \sigma$. الحل: الخطوة 1: $\partial = [v_1, v_2] - [v_0, v_2] + [v_0, v_1]$. النتيجة: $[v_1, v_2] - [v_0, v_2] + [v_0, v_1]$. الربط بالذكاء الاصطناعي: ثلاثة حواف.

مثال (3-2.46): حدّ الحدّ المعطيات: $\sigma = [v_0, v_1, v_2]$، نطبّق $\partial_1 \partial_2$. المطلوب: التحقّق من الصفر. الحل: الخطوة 1: $\partial_1(v_2 - v_1) - \partial_1(v_2 - v_0) + \partial_1(v_1 - v_0) = (v_2 - v_1) - (v_2 - v_0) + (v_1 - v_0) = 0$. النتيجة: 0.

الربط بالذكاء الاصطناعي: $\partial^2 = 0$.

مثال (4-2.46): مثلّث رباعيّ المعطيات: $\sigma = [v_0, v_1, v_2, v_3]$. المطلوب: $\partial_3 \sigma$. الحل: الخطوة 1: $-[v_1, v_2, v_3] + [v_0, v_2, v_3] - [v_0, v_1, v_3] + [v_0, v_1, v_2]$. النتيجة: 4 مثلّثات بإشارات متبادلة. الربط بالذكاء الاصطناعي: 4 وجوه.

مثال (5-2.46): عدد السلاسل (طول التوليد) المعطيات: مُعقّد بثلاث رؤوس وثلاث حواف ولا مثلّثات. المطلوب: $\dim C_0, \dim C_1, \dim C_2$. الحل: الخطوة 1: C_0 ثلاثة رؤوس، C_1 ثلاثة حواف، C_2 لا شيء. النتيجة: $(3, 3, 0)$. الربط بالذكاء الاصطناعي: متّجه-الوجه (f-vector).

مثال (6-2.46): مغلق على الوجوه المعطيات: مجموعة تحتوي مثلّثاً لا حوافه. المطلوب: هل مُعقّد صالح؟ الحل: الخطوة 1: لا، كلّ وجه لمُبسّط يجب أن ينتمي. النتيجة: غير صالح. الربط بالذكاء الاصطناعي: يستلزم الإغلاق.

مثال (7-2.46): مغلقة على التقاطع المعطيات: حافتان تشتركان في نقطة غير مدرجة. المطلوب: التحقّق. الحل: الخطوة 1: التقاطع (النقطة المشتركة) يجب أن يكون مُبسّطاً في المُعقّد. النتيجة: يجب إدراجه. الربط بالذكاء الاصطناعي: شرط التقاطع.

مثال (8-2.46): المُعقّد الممتلئ المعطيات: مثلّث بكلّ وجوه (3 رؤوس، 3 حواف، 1 مثلّث). المطلوب: هل صالح؟ الحل: الخطوة 1: نعم، كلّ وجوهه والإغلاق محقّقان. النتيجة: صالح. الربط بالذكاء الاصطناعي: قرص كامل.

مثال (9-2.46): الدوران (سلسلة ما) المعطيات: دورة $z = [v_0, v_1] + [v_1, v_2] + [v_2, v_0]$. المطلوب: $\partial_1 z$. الحل: الخطوة 1: $(v_1 - v_0) + (v_2 - v_1) + (v_0 - v_2) = 0$. النتيجة: 0 (دورة). الربط بالذكاء الاصطناعي: حدودي الدورات.

مثال (10-2.46): ليست دورة المعطيات: $z = [v_0, v_1]$ (حافة مفردة). المطلوب: $\partial_1 z$. الحل: الخطوة 1: $v_1 - v_0 \neq 0$ (ليست دورة). النتيجة: ليست دورة. الربط بالذكاء الاصطناعي: حافة مفتوحة.

مثال (11-2.46): سلسلة خطّيّة المعطيات: $c = 2[v_0, v_1] - 1[v_1, v_2]$. المطلوب: ∂c. الحل: الخطوة 1: $2(v_1 - v_0) - (v_2 - v_1) = 2v_1 - 2v_0 - v_2 + v_1 = 3v_1 - 2v_0 - v_2$. النتيجة: $3v_1 - 2v_0 - v_2$. الربط بالذكاء الاصطناعي: خطّيّة ∂.

مثال (12-2.46): المُعقّد الجزئيّ المعطيات: مجموعة جزء من K مُغلقة على الوجوه. المطلوب: التعريف. الحل: الخطوة 1: مُعقّد جزئيّ (subcomplex). النتيجة: يورّث البنية. الربط بالذكاء الاصطناعي: تحليل هرمي.

مثال (13-2.46): النجمة والحلقة المعطيات: نجمة v = كلّ مُبسّط يحوي v، والحلقة $\text{link}(v)$ = وجهها المُقابل. المطلوب: مثال على نجمة نقطة في مثلّث. الحل: الخطوة 1: نجمة v_0 = حافتان ومثلّث، الحلقة = حافة $[v_1, v_2]$. النتيجة: يصف الجوار. الربط بالذكاء الاصطناعي: طوبولوجيا محلّيّة.

مثال (14-2.46): أبعاد المُعقّد المعطيات: يحتوي مثلّثاً كأكبر مُبسّط. المطلوب: $\dim K$. الحل: الخطوة 1: 2 (أعلى بُعد مُبسّط). النتيجة: $\dim = 2$. الربط بالذكاء الاصطناعي: تحديد بُعد الفضاء.

مثال (15-2.46): خلاصة المعطيات: $\partial^2 = 0$. المطلوب: أهمّيته. الحل: الخطوة 1: يسمح بتعريف H_k (كسر الدورات على الحدود). النتيجة: أساس التجانس. الربط بالذكاء الاصطناعي: حجر الأساس.

أخطاء شائعة

- **نسيان إغلاق المُعقّد على الوجوه والتقاطعات:** يُنتج كيانات غير صالحة.
- **الخطأ في إشارات ∂:** الإشارات المتعاكسة ضروريّة لـ $\partial^2 = 0$.
- **الخلط بين المُبسّط والوجه:** الوجه مغطّى، المُبسّط أصغر وحدة.
- **نسيان خطّيّة ∂:** يمكن تمديده على السلاسل.

- **الخلط بين** $\dim C_k$ **(عدد المُبسّطات) والبُعد الطوبولوجيّ:** مختلفان.

صياغة رسمية: مجموعات الدورات والحدود والتجانس:

$$Z_k = \ker \partial_k, \qquad B_k = \operatorname{im} \partial_{k+1} \subseteq Z_k, \qquad H_k = Z_k / B_k \tag{2.46}$$

ورمزه $\beta_k = \dim H_k = \dim Z_k - \dim B_k$ (برتبة-الفراغ)؛ والخصيصة الأوليّة:

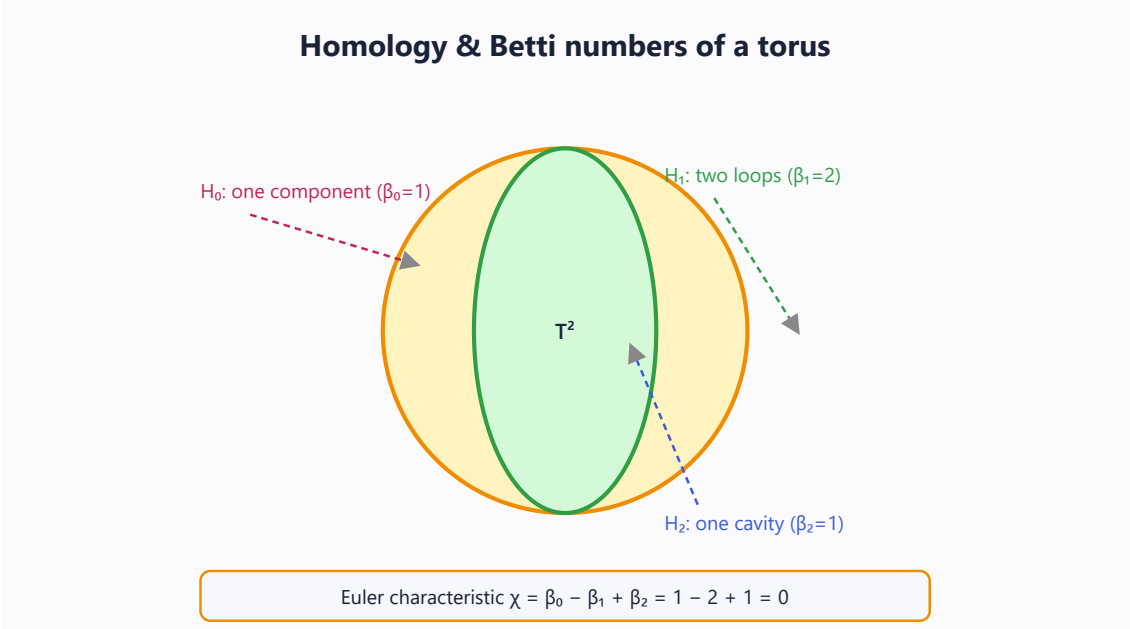
$$\chi = \sum_k (-1)^k \beta_k = \sum_k (-1)^k f_k \tag{3.46}$$

جدول الرموز

الرمز	المعنى
Z_k	الدورات (سلاسل لها حدّ صفر)
B_k	الحدود (معالم ∂_{k+1})
f_k	عدد المُبسّطات k-الأبعاد

الرسم

<figure> الشكل<figcaption> 2.46: الطارة T^2 بأرقام بيتيّ $\beta_0 = 1, \beta_1 = 2, \beta_2 = 1$ وخصيصة أويلر $\chi = 0$



شكل ٢.٤٦: *
التجان وأرقام بيتيّ

</figure> .</figcaption>0

البرهان

الخطوة 1 (التحقّي): $\operatorname{im} \partial_{k+1} \subseteq \ker \partial_k \Rightarrow \partial^2 = 0$ (كلّ حدّ هو دورة). ■

الخطوة 2 (المجموعة المميّزة): H_k قياس الدورات التي ليست حدوداً (الثقوب الحقيقيّة). ■

الخطوة 3 (خصيصة أويلر): $\sum (-1)^k f_k$ يتبدّل بالترتيب تيلورسوم–هوبر ليعطي $\sum (-1)^k \beta_k$. ■

خمسة عشر مثالاً محلولاً

مثال (3.46-1): نقطة مفردة المعطيات: مُعقّد برأس واحد فقط. المطلوب: β_k. الحل: الخطوة 1: $\beta_0 = 1$، لا حواف ولا وجوه $\Rightarrow$ البقيّة 0. النتيجة: $(\beta_0, \beta_1, \beta_2) = (1, 0, 0)$. الربط بالذكاء الاصطناعي: عنصر متّصل.

مثال (3.46-2): حافة (فاصل) المعطيات: رأسان وحافة. المطلوب: β. الحل: الخطوة 1: $\beta_0 = 1$ (موصول)؛ $\beta_1 = 0$ (حافة ملء، لا حلقة). النتيجة: $(1, 0, 0)$. الربط بالذكاء الاصطناعي: كامل واحد.

مثال (3.46-3): دائرة S^1 المعطيات: ثلاث رؤوس وثلاث حواف (مثلّث مجوّف). المطلوب: β. الحل: الخطوة 1: Z_1 حلقة واحدة (الدورة)؛ $B_1 = 0$ (لا مثلّثات) $\Rightarrow \beta_1 = 1$؛ $\beta_0 = 1$. النتيجة: $(1, 1, 0)$. الربط بالذكاء الاصطناعي: حلقة حقيقيّة.

مثال (3.46-4): كرة S^2 المطلوب: β (بتمثيل سطحيّ مجوّف). الحل: الخطوة 1: $\beta_0 = 1, \beta_1 = 0, \beta_2 = 1$. النتيجة: $(1, 0, 1)$. الربط بالذكاء الاصطناعي: فراغ محيط.

مثال (3.46-5): طارة T^2 المطلوب: β. الحل: الخطوة 1: $\beta_0 = 1, \beta_1 = 2, \beta_2 = 1$. النتيجة: $(1, 2, 1)$. الربط بالذكاء الاصطناعي: حلقتان وغرفَة.

مثال (3.46-6): قرص المعطيات: مثلّث مملوء. المطلوب: β والخصيصة. الحل: الخطوة 1: $\beta_0 = 1$؛ الحدّ H_1 صفر (الدورة حدّ مثلّث)؛ $\beta_2 = 0 \Rightarrow \chi = 1$. النتيجة: $\chi = 1$. الربط بالذكاء الاصطناعي: لا حلقة.

مثال (3.46-7): شكل رقم ثمانية المعطيات: دائرتان تتشاركان نقطة. المطلوب: β. الحل: الخطوة 1: $\beta_0 = 1$ (موصول)؛ $\beta_1 = 2$ (حلقتان مستقلّتان). النتيجة: $(1, 2, 0)$. الربط بالذكاء الاصطناعي: حلقتان حرّتان.

مثال (3.46-8): دائرتان منفصلتان المطلوب: β_0, β_1. الحل: الخطوة 1: $\beta_0 = 2$ (مكوّنان)؛ $\beta_1 = 2$ (حلقة لكلّ). النتيجة: $(2, 2, 0)$. الربط بالذكاء الاصطناعي: العناقيد المتعدّدة.

مثال (3.46-9): برتبة-الفراغ المعطيات: مُعقّد دائرّة مجوّفة: $\dim B_1 = 1, \dim Z_1 = 0$. المطلوب: β_1. الحل: الخطوة 1: $\beta_1 = 1 - 0 = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: حساب مباشر.

مثال (3.46-10): خصيصة أويلر للمثلّث المملوء المعطيات: $f_0 = 3, f_1 = 3, f_2 = 1$. المطلوب: χ. الحل: الخطوة 1: $3 - 3 + 1 = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: يطابق $\sum \beta$.

مثال (3.46-11): خصيصة أويلر للمثلّث المجوّف المعطيات: $f_0 = 3, f_1 = 3, f_2 = 0$. المطلوب: χ. الحل: الخطوة 1: $3 - 3 + 0 = 0$؛ وطول β: $1 - 1 + 0 = 0$. النتيجة: 0. الربط بالذكاء الاصطناعي: تطابق.

مثال (3.46-12): كرة بنصف قطر برمجيّ المطلوب: $\chi(S^2)$. الحل: الخطوة 1: $\chi = 2$؛ بأرقام بيتيّ $1 - 0 + 1 = 2$. النتيجة: 2. الربط بالذكاء الاصطناعي: فرق عن الطارة.

مثال (3.46-13): تفسير المعطيات: $\beta_0, \beta_1, \beta_2$. المطلوب: تفسير هندسيّ. الحل: الخطوة 1: عدد المكوّنات، الحلقات، الغرف (الفراغات المُغلقة). النتيجة: وصف شكليّ. الربط بالذكاء الاصطناعي: ميزات تفسيريّة.

مثال (3.46-14): حساب الدائرة بالبرمج المعطيات: مصفوفة حدّ ∂_1 لمثلّث. المطلوب: $\ker \partial_1$. الحل: الخطوة 1: النواة أحاديّةُ البُعد (الدورة الواحدة) $\Rightarrow \beta_1 = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: حساب عدديّ.

مثال (3.46-15): خلاصة المطلوب: دلالة β. الحل: الخطوة 1: β_k يعدّ الثقوب k-الأبعاد (الثقوب الحقيقيّة). النتيجة: عدّاد الثقوب. الربط بالذكاء الاصطناعي: توقيع شكل.

أخطاء شائعة

- **الخلط بين β_0 والمكوّنات:** β_0 عدد المكوّنات المتّصلة فقط للفضاء المتّصل.
- **نسيان أن الحدّ دورة:** كلّ حدّ نواة (من $\partial^2 = 0$).
- **الخلط بين $\dim Z_k$ وβ_k:** $\beta_k = \dim Z_k - \dim B_k$.

- **الاعتقاد أن خصيصة أويلر تغيّر بالتثليث:** بل ثابتة.
- **إغفال الحقل:** يُحسب H_k على حقل $\mathbb{F}$؛ عبر $\mathbb{Z}$ يظهر أثرٌ ترتيبيٌّ إضافيّ.

صياغة رسمية: تُرشَّح المُعقّد $K[0] \subseteq K[1] \subseteq \cdots \subseteq K[n]$ (مثلاً بنموّ ε في مُعقّد ڤيتوريس-ريبس). كلّ صفة في $H_k(K[a_i])$ إمّا تُولَد فتمتدّ إلى $K[a_j]$ أو تموت؛ يُلخّص ذلك بمدى استمرار $[b, d)$.

$$\text{Persistence} = d - b, \qquad \mathrm{PD}_k = \{[b_i, d_i)\} \text{ (متعدّدات الميلاد-الموت)} \tag{4.46}$$

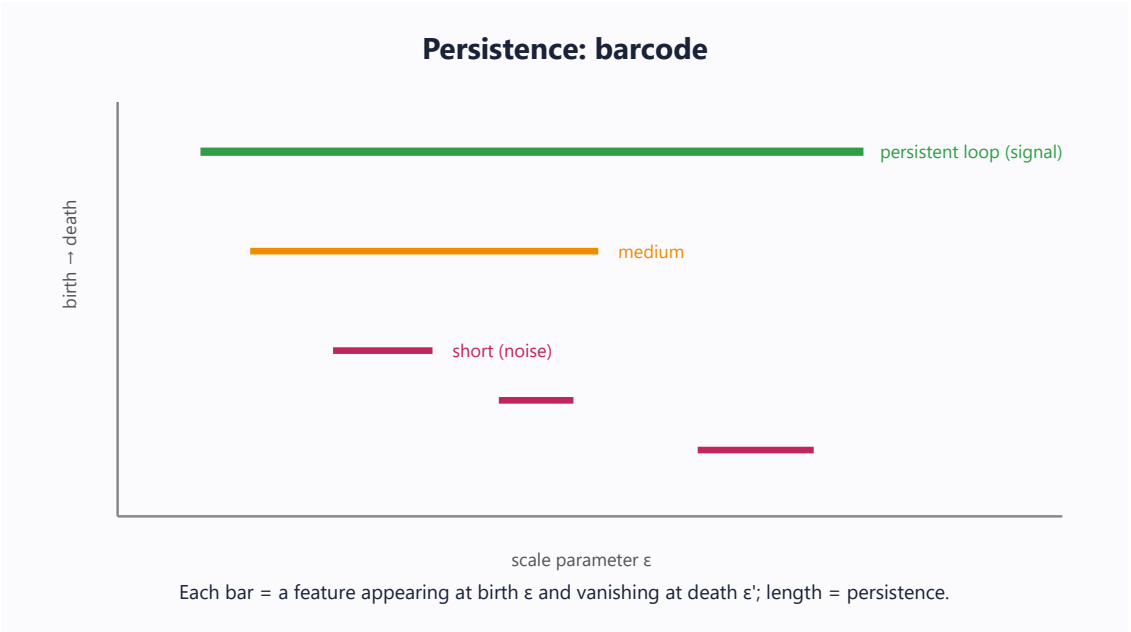
الأطوال الطويلة إشارات بنيويّة؛ القصيرة ضجيج.

جدول الرموز

الرمز	المعنى
PD	مخطط الاستمرار (بطاقة)
$[b, d)$	مدى الاستمرار (الميلاد–الموت)
Filtration	تسلسل المُعقّدات المتداخلة

الرسم

<figure> الشكل<figcaption> 3.46: بطاقة الاستمرار؛ الأشرطة الطويلة صفات حقيقيّة والقصيرة



شكل ٣.٤٦: *
التجانس الدائم

ضجيج.</figcaption> </figure>

البرهان

الخطوة 1 (تداخل المرشّح): $K[i] \subseteq K[j]$ عند $i \le j$ يُولّد رسمًا صاعدًا في التجان. ■
الخطوة 2 (نظريّة البنية): وحدات الاستمرار فوق حقل تتفكّك إلى مدى $[b, d)$ (نتيجة التجزئة). ■
الخطوة 3 (التمثيل): رسم بيانيّ لنقاط في المستوى $b < d$ = بَرْقِيّ (بطاقة). ■

خمسة عشر مثالاً محلولاً

مثال (46.4-1): نقاط منفصلة المعطيات: 5 نقاط عند $\varepsilon = 0$. المطلوب: β_0 في البداية. الحل: الخطوة 1: كلّ نقطة مكوّنها $\Rightarrow \beta_0 = 5$. النتيجة: 5. الربط بالذكاء الاصطناعي: عنق منفصل.

مثال (46.4-2): اندماج المكوّنات المعطيات: ε ينمو؛ اندماج نقطتين عند $\varepsilon = 0.2$، أخرى عند $\varepsilon = 0.8$. المطلوب: β_0 بعد الاندماج الكامل. الحل: الخطوة 1: باندماج العناقيد كلّها إلى مكوّن واحد $\beta_0 \to 1$ (عدد عمليّ يبقى β_0 بعدد العناقيد قبل اكتمال). النتيجة: 1 (إن اتّصلت). الربط بالذكاء الاصطناعي: عنق متّصل.

مثال (46.4-3): استمرار المكوّن المعطيات: نقطة تولدت عند $\varepsilon = 0.1$؛ اندمجت عند $\varepsilon = 0.9$؛نقطة أخرى $[0.05, 0.2]$. المطلوب: أيّهما ميزة أطول؟ الحل: الخطوة 1: $0.9 \to 0.1$ طوله 0.8؛$0.2 \to 0.05$ طوله 0.15. النتيجة: 0.8 إشارة. الربط بالذكاء الاصطناعي: تمييز ميزة عن ضجيج.

مثال (46.4-4): استمرار دائرة المعطيات: عيّنة من دائرة؛ حلقة H_1 تولد عند إغلاق المسار وتموت عند ملء الدائرة. المطلوب: صف الاستمرار. الحل: الخطوة 1: مدى طويل $\Rightarrow$ حلقة حقيقيّة (دائرة). النتيجة: إشارة دائريّة قويّة. الربط بالذكاء الاصطناعي: كشف الشكل الدائريّ.

مثال (46.4-5): ضجيج قصير المعطيات: نقاط عشوائيّة تولد مدى قصيرة. المطلوب: السلوك. الحل: الخطوة 1: ظهور واختفاء سريعان $\Rightarrow$ أشرطة قصيرة = ضجيج. النتيجة: أشرطة قصيرة. الربط بالذكاء الاصطناعي: فلترة الضجيج.

مثال (46.4-6): مرشّح أوليّ المعطيات: $K[0]$ فارغ؛$K[1]$ نقاط. المطلوب: β_0 في كلّ خطوة. الحل: الخطوة 1: 0 ثمّ 1 = لكلّ نقطة مضافة. النتيجة: يزاح f_k. الربط بالذكاء الاصطناعي: تتابع المرشّح.

مثال (46.4-7): مدى قابل للقراءة المعطيات: الميلاد $b = 0.3$؛الموت $d = 1.7$. المطلوب: الاستمرار. الحل: الخطوة 1: $1.4 = 0.3 - 1.7$. النتيجة: 1.4. الربط بالذكاء الاصطناعي: طول الشريط.

مثال (46.4-8): أقصى طول المعطيات: مديات $[0.2, 0.5), [0.1, 1.3), [0.6, 0.7)$. المطلوب: الأكثر استمراراً. الحل: الخطوة 1: $1.2 = 0.1 - 1.3$ الأطول. النتيجة: $[0.1, 1.3)$. الربط بالذكاء الاصطناعي: الصفة المهيمنة.

مثال (46.4-9): صفر طول المعطيات: $[b, b)$ (ميلاد وموت فوريّ). المطلوب: المعنى. الحل: الخطوة 1: صفة لحظيّة (بلا أثر) غالباً ضجيج عدديّ. النتيجة: ضجيج. الربط بالذكاء الاصطناعي: تجاهلها.

مثال (46.4-10): رسم ثنائيّ الأبعاد المعطيات: نقطتان إحداثاهما الميلاد/الموت. المطلوب: كيف نقارن مخططين؟ الحل: الخطوة 1: بالمسافة (bottleneck/Waterstein) بين المتعدّدات. النتيجة: مسافة المخططات. الربط بالذكاء الاصطناعي: ربط بـ(46.5).

مثال (46.4-11): ثبات المدى المتزامن المعطيات: صفة تبقى حيّة من b إلى d بلا موت. المطلوب: صياغة $[b, \infty)$. الحل: الخطوة 1: تدوم حتّى آخر المرشّح (مدى لا نهائيّ). النتيجة: $[b, \infty)$. الربط بالذكاء الاصطناعي: صفة بنيويّة دائمة.

مثال (46.4-12): مدى قصير حادثي المعطيات: طول 0.01. المطلوب: التصنيف. الحل: الخطوة 1: غالباً غير ذي دلالة (ضجيج). النتيجة: غير ذي دلالة. الربط بالذكاء الاصطناعي: عتبة عملية.

مثال (46.4-13): حساب استمرار H_0 في عيّنة المعطيات: 100 نقطة تتجمّع في 3 عناقيد. المطلوب: β_0 في المراحل. الحل: الخطوة 1: من 100 إلى 3 (بعد اندماجات داخل العناقيد). النتيجة: ثلاثة أشرطة طويلة H_0 (العناقيد). الربط بالذكاء الاصطناعي: تجميع طوبولوجيّ.

مثال (46.4-14): اختيار المقياس ε المعطيات: خطوات المرشّح. المطلوب: الأثر. الحل: الخطوة 1: دقّة أعلى $\Rightarrow$ بطاقة أدقّ وأكلف أكثر. النتيجة: مقايضة. الربط بالذكاء الاصطناعي: إعداد المرشّح.

مثال (46.4-15): خلاصة المطلوب: ما الذي يقيسه الاستمرار؟ الحل: الخطوة 1: مدة بقاء الصفة $\Rightarrow$ أهمّيتها البنيويّة. النتيجة: مدى الحياة. الربط بالذكاء الاصطناعي: ثبات الترتيب.

أخطاء شائعة

- **الخلط بين الاستمرار والدلالة:** كلّ مدى لا يعني إشارة؛ طويلة من هنا وهناك.
- **نسيان أن PD يتعدّداتها:** المتعدّد يسمح بعناصر متكرّرة (عديد التوأم).
- **الاعتماد على مرشّح خاطئ:** المرشّح السيّئ يُخفي أو يشوّش الميزات.
- **الخلط بين PD وبطاقة:** البطاقة مرئيّة، والمخطّط نقاط في المستوى (مكافئ).
- **إهمال البُعد k:** لكلّ بُعد مخططه المستقلّ.

صياغة رسمية: لدالتين $f, g : X \to \mathbb{R}$ على فضاء مثلّث (triangulable)، فإنّ مخططي استمرارهما متقاربان بمسافة لا تتجاوز فرق الدالّتين:

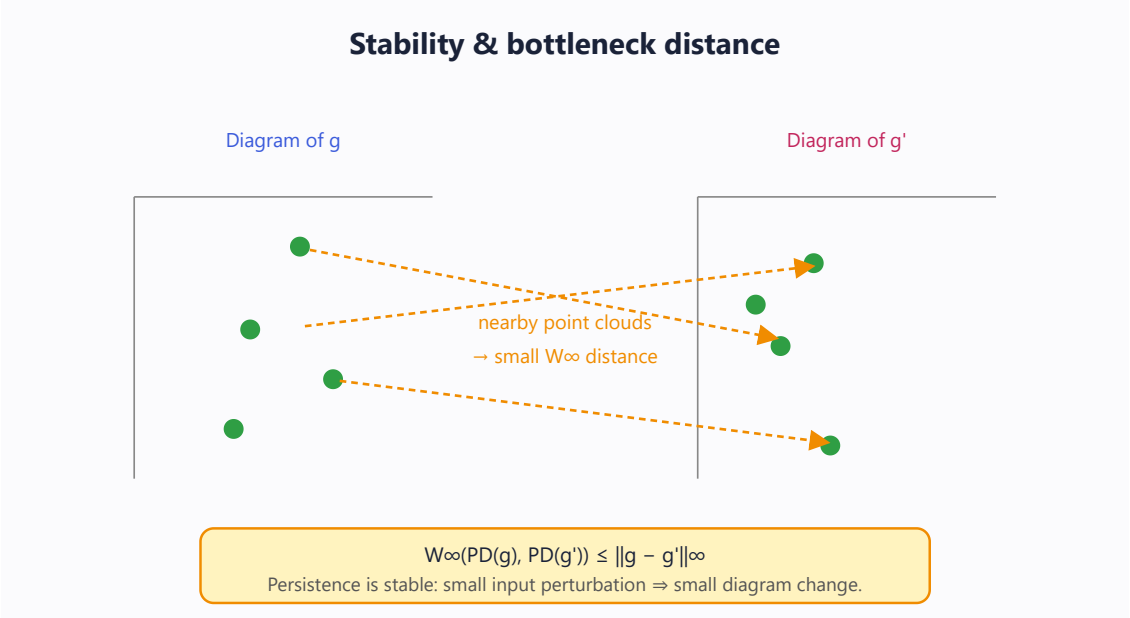
$$W_\infty\big(\mathrm{PD}(f), \mathrm{PD}(g)\big) \;\le\; \|f - g\|_\infty \tag{5.46}$$

جدول الرموز

الرمز	المعنى
$\mathrm{PD}(f)$	مخطط الاستمرار لـ f
W_∞	مسافة Wasserstein- ∞ (أقصى انطباق)
$\|f - g\|_\infty$	أقصى تغيّر في قيمة الدالّة

الرسم

<figure> الشكل<figcaption> 4.46: اضطراب صغير في الدالّة يُزيح المخطط (النقاط) بقدر صغير فقط.</figcaption>



شكل ٤٠٤٦: *
نظريّة الثبات

</figure>

البرهان

الخطوة 1 (دلالة المخطط): $\mathrm{PD}(f)$ متعدّدات نقاط $[b,d)$ للصفات المستمرة. ■

الخطوة 2 (الانطباق): نطابق نقاط المخططين بنفس التكلفة (انطباق جزئيّ). ■

الخطوة 3 (الثبات): إشارة مضطربة أُزواجٌ تُطابق بتكلفة≤الاضطراب (كوين-شتاينر/إديلسبرونر-هارر). ■

خمسة عشر مثالاً محلولاً

مثال (5.46-1): اضطراب صغير المعطيات: $f=[1,3,5,7]$، $g=[1.1,3,5.2,7]$ (اختلاف ≤ 0.2). المطلوب: أعلى حدّ للمسافة. الحل: الخطوة 1: $W_\infty \leq \|f-g\|_\infty = 0.2$. النتيجة: ≤ 0.2. الربط بالذكاء الاصطناعي: ثبات مقابل الضوضاء.

مثال (5.46-2): ثبات مع الضجيج المعطيات: $\varepsilon = 0.05$ ضجيج قِيَاسيّ. المطلوب: هل الثبات يحمي؟ الحل: الخطوة 1: المخطط يتحرّك $\leq \varepsilon$؛ الميزات الأطول من ε حقيقيّة. النتيجة: حماية جزئيّة. الربط بالذكاء الاصطناعي: تمييز إشارة عن ضجيج.

مثال (5.46-3): انطباق جزئيّ المعطيات: مخطط g بنقطتين، g' بثلاث. المطلوب: كيف نطابق؟ الحل: الخطوة 1: نطابق الأقرب، الزائد يطابق قطريّاً $(d=b)$ بتكلفة عمره/2. النتيجة: انطباق قُطريّ. الربط بالذكاء الاصطناعي: مقارنة قويّة.

مثال (5.46-4): تكلفة قُطريّة المعطيات: نقطة $(b,d)=(1,3)$؛غير مطابَقة. المطلوب: تكلفتها القُطريّة. الحل: الخطوة 1: $(d-b)/2=(3-1)/2=1$. النتيجة: 1. الربط بالذكاء الاصطناعي: تكلفة الميزة الهالكة.

مثال (5.46-5): انطباق مثاليّ المعطيات: تصوّران متطابقان. المطلوب: W_∞. الحل: الخطوة 1: 0 (تطابق تامّ). النتيجة: 0. الربط بالذكاء الاصطناعي: مسافة صفرية.

مثال (5.46-6): عتبة عمليّة المعطيات: ضجيج $\varepsilon = 0.1$؛إشارة مداها 0.8. المطلوب: الحكم. الحل: الخطوة 1: $0.8 > 0.1 \Rightarrow$ إشارة موثوقة. النتيجة: إشارة. الربط بالذكاء الاصطناعي: عتبة عمليّة.

مثال (5.46-7): ضجيج كبير المعطيات: إشارة 0.05؛ضوضاء 0.3. المطلوب: الحكم. الحل: الخطوة 1: الضوضاء تغطّي الإشارة؛ لا ثقة عالية. النتيجة: غير موثوق. الربط بالذكاء الاصطناعي: عدم ثقة.

مثال (5.46-8): تسمية "triangulable" المعطيات: متشعّب سطحيّ ناعم. المطلوب: الشرط. الحل: الخطوة 1: كلّ مشعّب ناعم مثلّث (cubulable) $\Rightarrow$ الثبات ينطبق. النتيجة: ينطبق واسعاً. الربط بالذكاء الاصطناعي: مشروط نظريّ.

مثال (5.46-9): ثبات الاختلاف لا التشابه المعطيات: مخطط قريب لا يعني دالّتين متشابهتين. المطلوب: توضيح. الحل: الخطوة 1: الثبات أحادي الاتجاه (الشكل $\Rightarrow$ المخطط). النتيجة: اتجاه واحد. الربط بالذكاء الاصطناعي: لا عكس للثبات.

مثال (5.46-10): الاستقرار عبر البعد H_٢ المعطيات: اضطراب ε،مخطط H_2. المطلوب: الحدّ. الحل: الخطوة 1: $W_\infty^{(2)} \leq \varepsilon$ كذلك (لكلّ بُعد). النتيجة: ينسحب على كلّ الأبعاد. الربط بالذكاء الاصطناعي: ثبات متعدّد الأبعاد.

مثال (5.46-11): تطبيق على الصور المعطيات: صورتان متقاربتان. المطلوب: ماذا يضمن الثبات؟ الحل: الخطوة 1: مخططات الاستمرار متقاربة $\Rightarrow$ وصف طوبولوجيّ مقاوم. النتيجة: مقاومة للاختلاف. الربط بالذكاء الاصطناعي: سمات بصريّة.

مثال (5.46-12): مقارنة بطرق أخرى المعطيات: الطرق العدديّة قد تفشل بضوضاء. المطلوب: فضل الثبات. الحل: الخطوة 1: يضمن ثباتاً لا تضمنه الوسائل غير المبنية عليه. النتيجة: ضمان نظريّ. الربط بالذكاء الاصطناعي: TDA قويّ.

مثال (5.46-13): حدّ تربيعيّ المعطيات: $\varepsilon = 0.01$ صغير جدّاً. المطلوب: المخطط يتحرّك. الحل: الخطوة 1: أقلّ من 0.01 عمليّاً (لا شيء تقريباً). النتيجة: ثابت تقريباً. الربط بالذكاء الاصطناعي: دقّة عالية.

مثال (14-5.46): تكلفة الانطباق الأقصى المعطيات: max تكلفة انطباق = $\max(|b'-b|, |d'-d|)$. المطلوب: الشكل (W_∞). الحل: الخطوة 1: انطباق يقلّل أقصى تكلفة. النتيجة: W_∞. الربط بالذكاء الاصطناعي: صيغة العمليّة.

مثال (15-5.46): خلاصة المطلوب: ما تضمنه النظريّة؟ الحل: الخطوة 1: استقرار الوصف الطوبولوجيّ أمام الضوضاء. النتيجة: استقرار مضمون نظريّاً. الربط بالذكاء الاصطناعي: أساس الثقة بـTDA.

أخطاء شائعة

- **ظنّ أن الثبات يضمن تقارب الدالّتين:** هو أحاديّ (شكل $\Rightarrow$ مخطط).
- **الخلط بين W_∞ والمتوسّط:** W_∞ يقيس أقصى انطباق لا المتوسّط.
- **نسيان تكلفة النقاط القُطريّة:** الأعداد المختلفة تُطابق قُطريّاً بثمن.
- **إغفال شرط "triangulable":** لا يسري على كلّ الفضاءات.
- **الظنّ أن أيّ ضوضاء تُفسد الإشارة:** ميزات أطول من الضوضاء تبقى موثوقة.

صياغة رسمية: لسحابة نقاط X ومقياس ε:

$$\check{C}(X,\varepsilon):\ \sigma\in\check{C}\iff\bigcap_{x\in\sigma}B(x,\varepsilon)\neq\emptyset,\qquad \mathrm{Rips}(X,\varepsilon):\ \sigma\text{ السيمبلكس لـ }\iff \mathrm{diam}(\sigma)\le\varepsilon \tag{6.46}$$

ولقناع (nerve lemma): $\check{C}(X,\varepsilon)$ متكافئ التشكيل مع اتحاد الكرات حين يكون الغطاء جيّداً.

جدول الرموز

الرمز	المعنى
$\mathrm{diam}(\sigma)$	أقصى مسافة بين نقاط σ
$B(x,\varepsilon)$	كرة نصف قطرها ε
nerve	مُعقّد التقاطعات
cover good	تقاطعات ذات اتّصال

الرسم

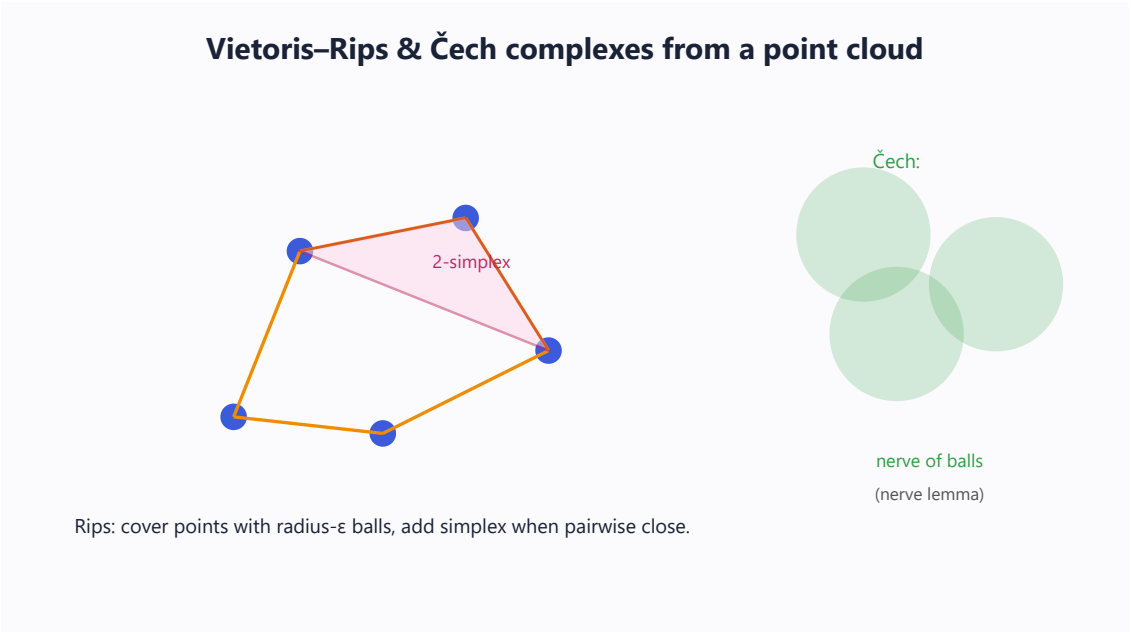
<figure> الشكل<figcaption> 5.46: مُعقّد ڤيتوريس-ريبس يجمع نقاطاً متقاربة؛ ومُعقّد Čech = nerve للكرات المُتقاطعة.</figcaption></figure>

البرهان

الخطوة 1 (ريبس ك-كليكات). أضف حافة عند كلّ مسافة $\le\epsilon$ ثمّ أكمِل بالكليكات $\Rightarrow$ clique = Rips complex. ■

الخطوة 2 (Čech = nerve): كلّ مجموعة ذات تقاطع مشترك مُبسّط $\Rightarrow$ nerve للغطاء الكُرَويّ. ■

الخطوة 3 (nerve lemma): إن كانت كلّ تقاطعات عقد منتظمة (قابلة للانكماش) فإنّ nerve يحفظ التجانس (بورسوك-ليراي). ■



شكل ٥.٤٦: * ريبس وČech

خمسة عشر مثالاً محلولاً

مثال (1-6.46): مربّع بأربع نقاط المعطيات: أربع نقاط ضلع 1، قُطر $\varepsilon = 1، \sqrt{2} \approx 1.414$. المطلوب: حواف Rips. الحل: الخطوة 1: الأضلاع مسافتها $1 \leq 1$ (حافة)؛الأقطار $1 < 414.1$ ⇒ لا. النتيجة: دورة C_4 (4 حواف). الربط للذكاء الاصطناعي: ربط الجوار.

مثال (2-6.46): β_1 عند $\varepsilon = 1$ المعطيات: المربّع من (1-6.46). المطلوب: β_1. الحل: الخطوة 1: دورة مغلقة بلا وجه ⇒ $\beta_1 = 1$. النتيجة: 1. الربط للذكاء الاصطناعي: حلقة مربّعة.

مثال (3-6.46): عند $\varepsilon = 1.5$ المعطيات: المربّع، $\varepsilon = 1.5$ (يشمل الأقطار). المطلوب: β_1. الحل: الخطوة 1: الأقطار تُضيف مثلّثات ⇒ تُملأ الدورة ⇒ $\beta_1 = 0$. النتيجة: 0. الربط للذكاء الاصطناعي: الحلقة تُملأ.

مثال (4-6.46): قطر يكفي المعطيات: قُطر 414.1. المطلوب: أقلّ ε لإضافة القطر. الحل: الخطوة 1: $\varepsilon \geq 1.414$. النتيجة: 1.414. الربط للذكاء الاصطناعي: عتبة المسافة.

مثال (5-6.46): Čech في المربّع المعطيات: كرات نصف قطرها 6.0 حول أربع الزوايا. المطلوب: هل تتقاطع كرات المتجاورة؟ الحل: الخطوة 1: ضلع $1 \leq 0.0+6.6=2.1$ ⇒ نعم (حافة في nerve). النتيجة: nerve على شكل دائرة (S^1). الربط للذكاء الاصطناعي: Čech أوسع.

مثال (6-6.46): Čech الأقطار المعطيات: كُرة 6.0؛قطُر $414.1 \leq 2.1$؟ المطلوب: تقاطع قُطريّ. الحل: الخطوة 1: $2.1 < 414.1$ ⇒ لا تقاطع قُطريّ. النتيجة: لا مثلّثات. الربط للذكاء الاصطناعي: Čech d أكثر.

مثال (7-6.46): lemma nerve عمليّاً المعطيات: كرات فوق مجموعة متماسكة. المطلوب: النتيجة. الحل: الخطوة 1: nerve يحفظ الاتّصال مركّز المكوّنات. النتيجة: حفظ الاتّصال. الربط للذكاء الاصطناعي: ربط Čech بالشكل.

مثال (8-6.46): غطاء جيّد المعطيات: تقاطعات شبكيّة. المطلوب: الشرط. الحل: الخطوة 1: كلّ تقاطع نهائيّ متّصل منتظماً (قابل للانكماش). النتيجة: lemma nerve يتحقّق. الربط للذكاء الاصطناعي: ضبط المقياس.

مثال (9-6.46): Rips نظريّاً vs حسابيّاً المعطيات: نقطتان بمسافة 3.0. المطلوب: ε للربط. الحل: الخطوة 1: $\varepsilon \geq$

0.3 يكفي لحافة واحدة. النتيجة: 0.3. الربط بالذكاء الاصطناعي: عتبة المسافة.

مثال (10-6.46): تعقيد Rips المعطيات: n نقطة، ε صغير. المطلوب: نموّ عدد الحواف. الحل: الخطوة 1: $O(n^2)$ حافة؛ المثلّثات $O(n^3)$ في Rips. النتيجة: أُسّي في البُعد. الربط بالذكاء الاصطناعي: تناثر مقبول.

مثال (11-6.46): خدعة البُعد العالي المعطيات: بيانات عالية البُعد. المطلوب: مشكلة Rips. الحل: الخطوة 1: عدد المُبسّطات أُسّيّ في البُعد ⇒ مكلف ⇒ تقليل العيّنة/التقريب. النتيجة: مُكلِف بُعدانيّاً. الربط بالذكاء الاصطناعي: حلول عمليّة.

مثال (12-6.46): Čech عكسيّ أسهل المعطيات: Čech يحتاج تقاطعات فعليّة. المطلوب: المقارنة. الحل: الخطوة 1: Čech أعقد حسابيّاً ⇒ نُفضّل Rips عمليّاً. النتيجة: Rips شائع عمليّاً. الربط بالذكاء الاصطناعي: اختيار شائع ومُفضّل.

مثال (13-6.46): نقاط على دائرة المعطيات: عيّنة k نقطة على S^1. المطلوب: متى يظهر β_1؟ الحل: الخطوة 1: عند ε أكبر من الفراغ (الخطوة) وأصغر من القطر ⇒ $\beta_1 = 1$. النتيجة: حلقة تعيش فترةً واسعة. الربط للذكاء الاصطناعي: اكتشاف الدائرة.

مثال (14-6.46): الفرق مع التجانس الدائم المعطيات: مرشّح ε لRips. المطلوب: ماذا نحسب؟ الحل: الخطوة 1: التجان الدائم لسلسلة Rips(X, ε) = الدائم. النتيجة: تجان دائم. الربط للذكاء الاصطناعي: يربط بـ(4.46).

مثال (15-6.46): خلاصة المطلوب: ريبس مقابل Čech. الحل: الخطوة 1: ريبس أبسط وأكثر شيوعاً؛ Čech أقرب لـnerve، lemma. النتيجة: ريبس عمليّ، Čech نظريّ. الربط للذكاء الاصطناعي: اختيار بحسب المهمّة.

أخطاء شائعة

- **الخلط بين شرط ريبس (قطر) وČech (تقاطع):** مختلفان اختلافاً دقيقاً.
- **نسيان أنّ ريبس = complex: clique** أكمله الحواف إلى كليكات.
- **إغفال شرط الغطاء الجيّد في lemma: nerve** بدونه لا تجان.
- **الظنّ أن Čech يظهر ريبس:** القيم المعتبَرة قد تختلف.
- **إهمال اليُسْر:** lemma nerve يعطي تشاكُلاً (homology) لا هوية.

صياغة رسمية: لعيّنة X ودالّة مُرشّح $f : X \to Z$ مغطّاة بمجموعات متداخلة $\mathcal{U} = \{U_i\}$ لـZ، نبني:

١. لكلّ U_i، خذ العيّنة الجزئيّة $X_i = f^{-1}(U_i) \cap X$.

٢. جمّع كلّ X_i (حسب خوارزميّة تجميع) إلى عناقيد.

٣. العقد = العناقيد، والحواف = إذا تقاطعت (تشترك في نقطة).

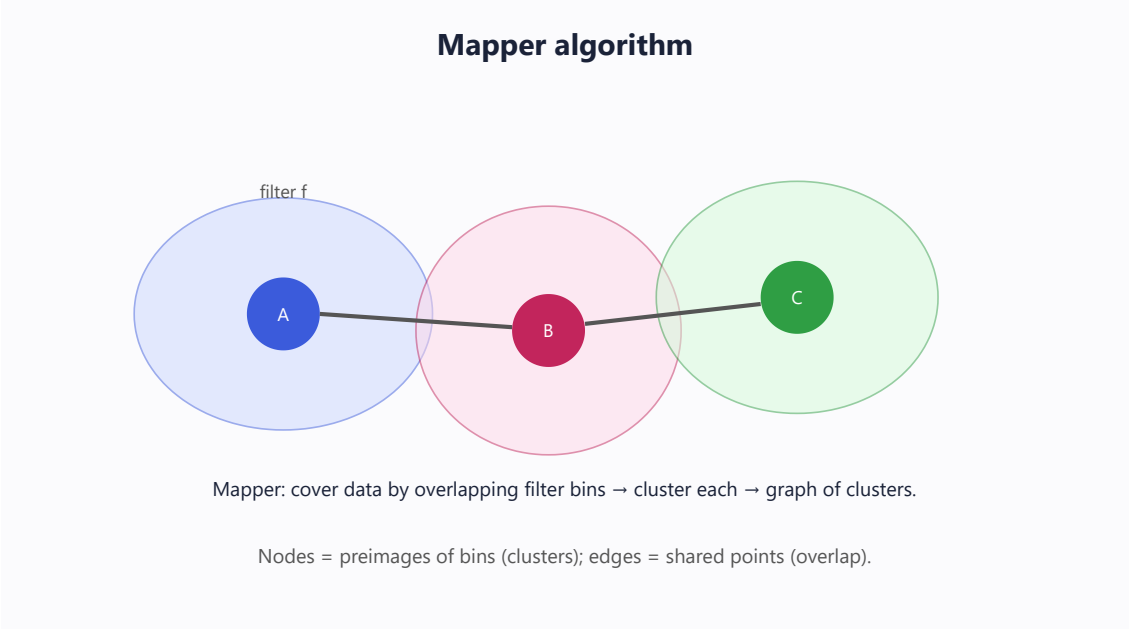
الرسم الناتج "مخطّط" يحفظ البنية الشكليّة العاليّة للبيانات.

جدول الرموز

الرمز	المعنى
f	دالّة المُرشّح (filter)
X_i	العيّنة الجزئيّة قبل التجميع
node/edge	العنقود / تقاطع العناقيد

الرسم

<figure> الشكل<figcaption> 6.46: مُرشِّح يغطّي البيانات؛ تُجمَّع كلّ خلية؛ والمخطّط يحفظ الشكل.</figcaption>



شكل ٦.٤٦: *
مخطّط

</figure>

البرهان

الخطوة 1 (الترشيح): خيار f يُظهر البُعد المثير للاهتمام (كثافة، إسقاط، قيمة دالّة). ■

الخطوة 2 (العناقيد): التجميع داخل كلّ خلية يلتقط المكوّنات المحليّة. ■

الخطوة 3 (الـNerve): التقاطعات تصبح حوافّ ⇒ رسم مشابه للـnerve، يعرض البنية العالميّة. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.46): مخطّط لبيانات دائريّة المعطيات: نقاط على دائرة؛ f = الإسقاط على محور. المطلوب: شكل المخطّط. الحل: الخطوة 1: القطبان يشتركان في شرائح ⇒ عقدتان موصولتان بحافة ⇒ مخطّط حلقيّ. النتيجة: حلقة (مثل الأصل). الربط بالذكاء الاصطناعي: يستعيد الشكل.

مثال (2-7.46): فراغ ضجيجيّ المعطيات: 4 نقاط لا علاقة بينها؛ f = كثافة. المطلوب: المخطّط. الحل: الخطوة 1: عناقيد مفردة بلا تقاطعات ⇒ عقد معزولة. النتيجة: 4 عقد منفصلة. الربط بالذكاء الاصطناعي: يظهر الانفصال.

مثال (3-7.46): خطوات اختيار المُرشِّح المعطيات: بيانات 10-أبعاد. المطلوب: كيف نُرشِّح؟ الحل: الخطوة 1: نُسقط بـPCA أو نستخدم كثافة نواة. النتيجة: إسقاط ذكي. الربط بالذكاء الاصطناعي: تحضير جيّد.

مثال (4-7.46): أثر التغطية المعطيات: تغطية دقيقة (خلايا كثيرة) مقابل خشنة. المطلوب: الأثر. الحل: الخطوة 1: دقيقة ⇒ عقد وحوافّ أكثر ⇒ تفاصيل أدقّ وضوضاء أكثر. النتيجة: مقايضة الدقّة. الربط بالذكاء الاصطناعي: اختيار الدقّة.

مثال (46.7-5): التجانس مقابل الامتداد المعطيات: بيانات في فرعين. المطلوب: ماذا يلتقط؟ الحل: الخطوة 1: فرعان منفصلان ⇒ عنقودان؛ إن اتّصلا بحافة واحدة ⇒ مخطّط حلقي. النتيجة: يفرّق ويصل. الربط بالذكاء الاصطناعي: كشف البنية.

مثال (46.7-6): عدد الإسقاطات المعطيات: f بقيم متعدّدة. المطلوب: عدد الشرائح $d(f)$. الحل: الخطوة 1: في كلّ فترة شرائح، مثلاً 10 شرائح = 10 طبقات تحليل. النتيجة: طبقات مُتعدّدة. الربط بالذكاء الاصطناعي: قابل للتبديل.

مثال (46.7-7): ربط بـpersistence المعطيات: كثافة كـf. المطلوب: هل يحفظ؟ الحل: الخطوة 1: نعم، المخطّط يلتقط H_1, H_2 (حلقة أو فراغات). النتيجة: شكل شاهد. الربط للذكاء الاصطناعي: ربط بـpersistence.

مثال (46.7-8): اختيار التجمع المعطيات: التجميع بـDBSCAN مقابل k-means. المطلوب: الأثر. الحل: الخطوة 1: اختيار خوارزميّة التجميع يؤثّر على العقد؛ يستحسن ثباتاً (DBSCAN). النتيجة: يحتاج ثبات. الربط للذكاء الاصطناعي: حساسيّة للطريقة.

مثال (46.7-9): ربط بـgraph Reeb المعطيات: دالّة سلسة على مشعّب. المطلوب: العلاقة. الحل: الخطوة 1: المخطّط تقدير مُشتقّ من graph Reeb (باستعمال التجميع). النتيجة: تقدير Reeb. الربط للذكاء الاصطناعي: أساس نظريّ.

مثال (46.7-10): تطبيق على صورة المطلوب: مثال. الحل: الخطوة 1: نُرشّح بسطوع البكسل؛ المخطّط يبين مناطق متّصلة (أجزاء الصورة). النتيجة: تقسيم شكليّ. الربط للذكاء الاصطناعي: رؤية حاسوبيّة.

مثال (46.7-11): خصائص الاستمرار المعطيات: بطاقات مُرشّحات متعدّدة. المطلوب: الفائدة. الحل: الخطوة 1: نرى كيف تتغيّر الميزات بتغيّر المُرشّح (ثبات شكل عبر مقاييس). النتيجة: تحليل متعدّد المقاييس. الربط بالذكاء الاصطناعي: متانة للضوضاء.

مثال (46.7-12): تعقيد الحساب المعطيات: n عيّنة، m خلية، c تجميع. المطلوب: التعقيد. الحل: الخطوة 1: m تجميع + nerve ⇒ نحو $O(n \cdot mc)$ تقريباً. النتيجة: خطّيّ تقريباً. الربط للذكاء الاصطناعي: قابل للتوسّع.

مثال (46.7-13): مخطّط عدديّ المعطيات: بيانات X على شكل 8. المطلوب: شكل المخطّط بالنظر للإسقاط. الحل: الخطوة 1: فرعان يتقاطعان ⇒ عقدة ذات ثلاث حواف (شكل العدد 8). النتيجة: عقدة ثلاثيّة. الربط للذكاء الاصطناعي: كشف الأشكال العشريّة.

مثال (46.7-14): اختيار غطاء بواجهة f المعطيات: نرغب في إبراز تقلّب C. المطلوب: كيف؟ الحل: الخطوة 1: نختار f يتباين حول C (تُظهر أنماطًا مثيرة). النتيجة: قرار مستنير. الربط للذكاء الاصطناعي: تصميم المُرشّح.

مثال (46.7-15): خلاصة المطلوب: ماذا يقيس المخطّط. الحل: الخطوة 1: البنية الشكليّة العالميّة متعدّدة المقاييس للبيانات. النتيجة: وصف شكليّ. الربط للذكاء الاصطناعي: استكشاف shapes.

أخطاء شائعة

- **الاعتماد على مُرشّح خاطئ:** يُظهر بُعداً غير ذي دلالة.
- **الخلط بين المخطّط والتجانس الدائم:** المخطّط أعمّ وأكثر خصوصيّة.
- **الاعتقاد بأنّ العدد العالي للعقاديد أفضل:** ضوضاء وإفراط.
- **نسيان أنّ التجميع يلعب دوراً حاسماً:** تغييره يغيّر الرسم.
- **إغفال تأثّر الميزات بالمُرشّح:** تغيير f قد يُبرز بنيةً مختلفة.

صياغة رسمية: لتحويل التجان الدائم إلى ميزات قابلة للتعلّم نلجأ إلى أحد الخطوط: (1) مناظر الاستمرار (persistence landscapes) دالّيّة قابلة للمتوسّط؛ (2) صور الاستمرار (persistence images) متّجهة الحجم الثابت؛ (3) نُوى الاستمرار (persistence kernels) على المخطّطات:

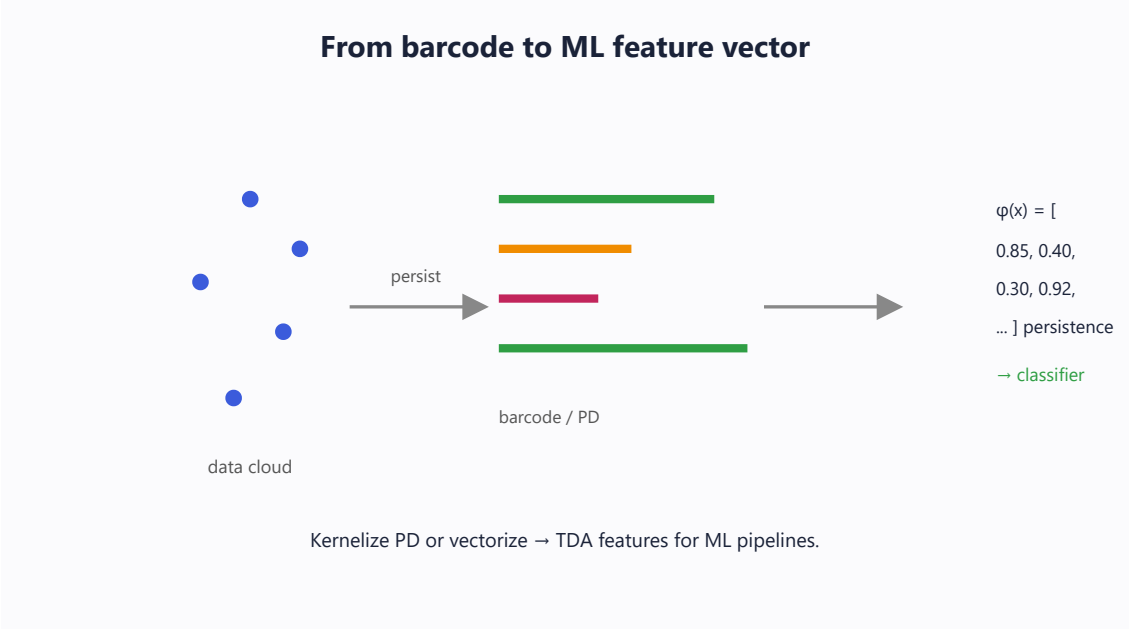
$$\lambda_k(t) = \text{القيمة الكونيّة}(b,d)\ t \mapsto \min(t-b,\ d-t) \ : \text{العظمى الكونيّة} \tag{7.46}$$

جدول الرموز

الرمز	المعنى
$\lambda_k(t)$	المنظور الاستمراري k-الأعلى
$w(b,d) = d - b$	وزن الاستمرار
$k(\cdot,\cdot)$	نواة على المخطّطات

الرسم

<figure> الشكل<figcaption> 7.46: من بطاقة الاستمرار إلى متّجه ميزات يُغذّي مصنّفاً أو نواة.</figcaption>



شكل ٧٠٤٦: *
TDA للتعلّم

</figure>

البرهان

الخطوة 1 (المناظر): المنظور الاستمراريّ دالّة متدرّجة $\Rightarrow$ يقبل التكامل والمتوسّط والنُوى. ■

الخطوة 2 (الصور): تُوزَّع نقاط المخطّط في شبكة بدالّة غوسيّة موزونة = متّجه ثابت البُعد. ■

الخطوة 3 (النُوى): نواة أُسّيّة $k = e^{-\lambda W_p}$ تكون صحيحةً (لأنّ W_p أقصى و$\lambda \geq 0$). ■

خمسة عشر مثالاً محلولاً

مثال (8.46-1): منظار لمدى واحد المعطيات: مدى واحد $[0.2, 0.8]$،نُشكّل المنظور $\lambda_1(t) = \min(t - 0.2, 0.8 - t)$. المطلوب: قمّة المنظور. الحل: الخطوة 1: يتساوى الاسمان عند $t - 0.2 = 0.8 - t \Rightarrow t = 0.5$؛ القيمة 0.3. النتيجة: 0.3. الربط للذكاء الاصطناعي: نقطة استمرار.

مثال (8.46-2): منظر بمدين المعطيات: $[0.1, 0.5]$ و$[0.4, 1.0]$. المطلوب: $\lambda_1(0.45)$. الحل: الخطوة 1: $g_1 = \min(0.45 - 0.1, 0.5 - 0.45) = \min(0.35, 0.05) = 0.05$؛ $g_2 = \min(0.45 - 0.4, 1.0 - 0.45) = \min(0.05, 0.55) = 0.05$؛ $\lambda_1 = 0.05$. النتيجة: 0.05. الربط للذكاء الاصطناعي: تجميع المدين.

مثال (8.46-3): منظور مباشر المعطيات: مدى $[0.0, 1.0]$؛$\lambda_1(0.5)$. المطلوب: القيمة. الحل: الخطوة 1: $\min(0.5, 0.5) = 0.5$. النتيجة: 0.5. الربط للذكاء الاصطناعي: أقصى استمرار.

مثال (8.46-4): صورة استمرار المعطيات: نقطة $(b, d) = (0.2, 0.8)$ بوزن 0.6. المطلوب: كيف تُرسم؟ الحل: الخطوة 1: غاوسيّة مركزّها (b, d) مقيّمة بـ$w = 0.6$. النتيجة: بقعة غوسيّة. الربط للذكاء الاصطناعي: تمثيل متّجهيّ ثابت.

مثال (8.46-5): ثبات المتّجه المعطيات: عيّنتان بمخطّطات مختلفة الحجم. المطلوب: حجم صورة الاستمرار. الحل: الخطوة 1: محدّد مسبقاً (شبكة) لا يتغيّر بعدد النقاط. النتيجة: ثابت. الربط للذكاء الاصطناعي: مثال.

مثال (8.46-6): نواة على المخطّطات المعطيات: $W_2(PD, PD') = 0.3$،$\lambda = 2$. المطلوب: قيمة النواة الأُسّيّة. الحل: الخطوة 1: $k = e^{-2 \times 0.3} = e^{-0.6} = 0.549$. النتيجة: 0.549. الربط للذكاء الاصطناعي: تشابه طوبولوجيّ.

مثال (8.46-7): نواة تكامليّة المعطيات: $\lambda = 1$،$W_2 = 1.5$. المطلوب: k. الحل: الخطوة 1: $e^{-1.5} = 0.223$. النتيجة: 0.223. الربط للذكاء الاصطناعي: تشابه أبعد.

مثال (8.46-8): صنفان المعطيات: صنف أ دائريّ (حلقة قويّة)؛صنف ب عنقوديّ. المطلوب: كيف يفصل TDA؟ الحل: الخطوة 1: مدى H_1 طويل لأ، غائب عمليّاً لب. النتيجة: تفريق مباشر. الربط للذكاء الاصطناعي: تصنيف شكليّ.

مثال (8.46-9): متّجه الميزات المعطيات: مناظر $\lambda_1(0.3) = 0.4$،$\lambda_1(0.6) = 0.2$،$\beta_0 = 2$. المطلوب: متّجه ϕ. الحل: الخطوة 1: $\phi = [0.4, 0.2, 2]$ (أ وتثبيت بقاء). النتيجة: ϕ ثلاثيّ. الربط للذكاء الاصطناعي: يُغذّي مصنّفاً.

مثال (8.46-10): مزج TDA بالخصائص المعطيات: 50 خاصّية كلاسيكيّة + 5 طوبولوجيّة. المطلوب: الفائدة. الحل: الخطوة 1: TDA تضيف بعداً شكليّاً قد يفصّل حالاتٍ يصعب على الكلاسيكيّات. النتيجة: ميزات تكميليّة. الربط للذكاء الاصطناعي: تعزيز الأداء.

مثال (8.46-11): تصنيف شكليّ المعطيات: نموذج صنفين. المطلوب: لماذا مناسب للبيانات الشكليّة. الحل: الخطوة 1: يدعم اندماجات كاملة وصياغةً شكليّة ثابتة. النتيجة: مثاليّ للشكل. الربط للذكاء الاصطناعي: حالة مثاليّة.

مثال (8.46-12): تعقيد المشروع المعطيات: n عيّنة $\times m$ نقطة؛بناء Rips + استمرار. المطلوب: التعقيد. الحل: الخطوة 1: نحو $O(n(m^3))$ (كثافة)؛ بالتقريب أقلّ. النتيجة: مُكلِف. الربط للذكاء الاصطناعي: قابل للتوسّع بتقليل الأبعاد.

مثال (8.46-13): ثبات المخطّط المعطيات: عيّنة مع ضوضاء ε. المطلوب: ماذا يضمن الاستقرار؟ الحل: الخطوة 1: المخطّط يتحرّك $\leq \varepsilon$ (ثابت نظريّاً)؛ النواة تعكس ذلك. النتيجة: استقرار. الربط للذكاء الاصطناعي: مقاومة الضوضاء.

مثال (8.46-14): طبقة تفاضلية المعطيات: TDA كطبقة في شبكة. المطلوب: متى؟ الحل: الخطوة 1: عندما نريد دالّةً قابلة للتعلّم من الاستمرار (طرق حديثة). النتيجة: TDA تعلّمي. الربط للذكاء الاصطناعي: تفاضليّة.

مثال (8.46-15): خلاصة المطلوب: ما يضيفه TDA للتعلّم؟ الحل: الخطوة 1: ميزات شكليّة مستقرّة (حلقات، فراغات، اتّصال) تدعم التعميم. النتيجة: قوّة شكليّة. الربط للذكاء الاصطناعي: بعد إضافيّ.

أخطاء شائعة

- **الخلط بين المنظور والصورة:** المنظور دالّة، والصورة متّجه شَبَكِيّ.
- **نسيان وزن الاستمرار:** كلّ نقطة بوزن طولها لا وزن موحّد.
- **الظنّ أنّ النواة أُسّيّة صالحة دائماً:** تلزمها W_p أقصى و$\lambda \geq 0$.
- **إغفال تعقيد الحساب:** بناء المُعقّدات مكلف للبيانات الكثيفة.
- **تجاهل البُعد:** لكلّ بُمدى k مخططه ومنظاراته المستقلّة.

جدول تجميع النظريات

النظرية	العنوان	المعادلة المحوريّة	الرسم
2.46	المُعقّدات والحدّ	$\partial^2 = 0$	fig-4601
3.46	التجان وأرقام بيتّي	$H_k = Z_k/B_k$، χ	fig-4602
4.46	التجان الدائم	مدى استمرار $[b, d)$	fig-4603
5.46	ثبات التجان	$W_\infty \leq \|f - g\|_\infty$	fig-4604
6.46	ڤيتوريس-ريبس وČech	lemma nerve	fig-4605
7.46	المخطّطات (Mapper)	مُرشِّح+تجميع+nerve	fig-4606
8.46	TDA والتعلّم	منظورات/صور/نُوى	fig-4607

عشرون تمريناً محلولاً (إجابات موجزة)

١. (∂^2) مثلّث، $\partial\partial = 0$.

٢. f **(vector-)** مثلّث مجوّف — $(3, 3, 0)$.

٣. β **(القطعة)** حافة — $(\beta_0, \beta_1) = (1, 0)$.

٤. **(دائرة)** S^1 — $(\beta_0, \beta_1) = (1, 1)$.

٥. **(طارة)** T^2 — $(1, 2, 1)$؛ $\chi = 0$.

٦. **(درجة)** قرص مملوء — $\chi = 1$.

٧. **(Rank-nullity)** $\beta_1 = 1 - \dim Z_1 = 2, \dim B_1 = 1$.

٨. **(استمرار)** $[0.3, 1.7)$ — 1.4.

٩. **(مركّز منفصل)** 5 نقاط — $\beta_0 = 5$ آنيّاً.

١٠. **(ثبات)** $\|f - g\|_\infty = 0.2$ — $W_\infty \leq 0.2$.

١١. **(وميض قُطريّ)** نقطة $(1, 3)$ غير مطابقة — تكلفة 1.

١٢. **(ريبس)** مربّع ضلع 1، $\varepsilon = 1$ — دورة C_4؛ $\beta_1 = 1$.

١٣. **(ريبس)** نفس المربّع، $\varepsilon = 1.5$ — $\beta_1 = 0$.

١٤. **(Čech)** كرات 6.0 (ضلع 1) — نعم؛ قُطر 414.1 — لا.

١٥. **(منظور)** مدى $[0.2, 0.8]$ — ذروة $\lambda_1 = 0.3$ عند $t = 0.5$.

١٦. **(منظور مركّب)** $\lambda_1(0.45)$ للمدين — 0.05.

١٧. **(نواة)** $W_2 = 0.3, \lambda = 2$ — 0.549.

١٨. **(عناقيد)** 5 نقاط تتجمّع في 3 عناقيد — 3 أشرطة H_0 طويلة.

١٩. **(مخطّط)** بيانات على دائرة — مخطّط حلقيّ.

٢٠. **(متّجه ميزة)** منظار $\beta_0 = 2$،$0.4, 0.2$ — $\phi = [0.4, 0.2, 2]$.

فهرس الرموز

الرمز	المعنى	أول ورود
∂_k	مشغّل الحدّ	2.46
Z_k, B_k, H_k	الدورات، الحدود، التجان	3.46
β_k	رقم بيتّي	3.46
PD	مخطط الاستمرار	4.46
W_∞	مسافة Wasserstein-∞	5.46
$\lambda_k(t)$	المنظور الاستمراريّ	8.46

المراجع

- J. Harer, H., Edelsbrunner, (2010). *Computational Topology: An Introduction*. AMS.
- A. Zomorodian, D., Letscher, H., Edelsbrunner, (2002). *Topological Persistence and Simplification*. Discrete & Computational Geometry.
- G. Carlsson, (2009). *Topology and Data*. Bulletin of the AMS.
- J. Harer, H., Edelsbrunner, D., Cohen-Steiner, (2007). *Stability of Persistence Diagrams*. Discrete & Computational Geometry.
- G. Carlsson, A., Zomorodian, (2005). *Computing Persistent Homology*. Discrete & Computational Geometry.
- G. Carlsson, F., Mémoli, G., Singh, (2007). *Topological Methods for the Analysis of High Dimensional Data Sets and 3D Object Recognition*. SPBG.

نظرية الفئات والذكاء الاصطناعي التركيبي

«التركيب هو جوهر التفكير الرياضيّ؛ ونظرية الفئات تجعل التركيب نفسه موضوعاً للدرس المنهجيّ.»

عندما نبني نماذج تعلّم ضخمة، لا نجمع أرقاماً عشوائيّاً بل نركّب وحدات: طبقة فوق طبقة، محوّل فوق محوّل، نموذج فوق نموذج. نظرية الفئات تُعطي لغةً دقيقة لهذا التركيب: الكائنات، والسهام، والمُقوّبات، والتحويلات الطبيعيّة، والفئات المونويّدة، والعدسات والبصريات، وبهذا تُصبح بنية الشبكة والتدرّج العكسيّ تركيباً محكومُه قواعدُ رياضيّةٌ عامّة. سبع نظريات:

- **2.47 الفئات والمُقوّبات** — كائنات، سهام، تركيب، هوية؛ والمُقوّب يحفظها.
- **3.47 التحويلات الطبيعيّة والخصائص العالميّة** — $\alpha : F \Rightarrow G$؛ الجداء، والمرافقة.
- **4.47 الفئات المونويّدة** — $\otimes$، والرسوم الشريطيّة للتعبير عن التركيب.
- **5.47 المونادات** — T مع η وμ وقوانين الوحدة والترابط.
- **6.47 العدسات والبصريات** — (get, set) وتعميمها للتحويلات ثنائيّة الاتجاه.
- **7.47 قواعد البيانات الفئويّة** — المخطط فئة، والبيانات مُقوّب، والنقل مُقوّباً.
- **8.47 التركيبية في التعلّم والنشر العكسي** — الشبكة بصريات، والتركيب يحفظ التدرّج.

كلّ نظرية تتبع القالب: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
$\mathrm{Ob}(\mathcal{C})$	كائنات الفئة	عُقَد
$\mathrm{Hom}_{\mathcal{C}}(A, B)$	سهام من A إلى B	morphisms
$g \circ f$	تركيب السهمين	ترابطيّ
id_A	سهم الهويّة	محايد
$F : \mathcal{C} \to \mathcal{D}$	مُقوّب	يحفظ التركيب
$\alpha : F \Rightarrow G$	تحويل طبيعيّ	مربّع طبيعيّ
$\otimes$	جداء مونيّد	متوازٍ

الاتفاقيات: نكتب $f : A \to B$ للسهم؛ التركيب يُقرأ من اليمين (f ثمّ g = «$g \circ f$»). كلّ المعادلات في كتل LTR.

صياغة رسمية: الفئة $\mathcal{C}$ تتكوّن من كائنات وسهام وتركيب وهويّة تحقّق الترابطيّة والحياديّة:

$$(h \circ g) \circ f = h \circ (g \circ f), \qquad \mathrm{id}_B \circ f = f = f \circ \mathrm{id}_A \tag{1.47}$$

والمُقوّب $F : \mathcal{C} \to \mathcal{D}$ يرسل الكائنات إلى كائنات والسهام إلى سهام بحفظ:

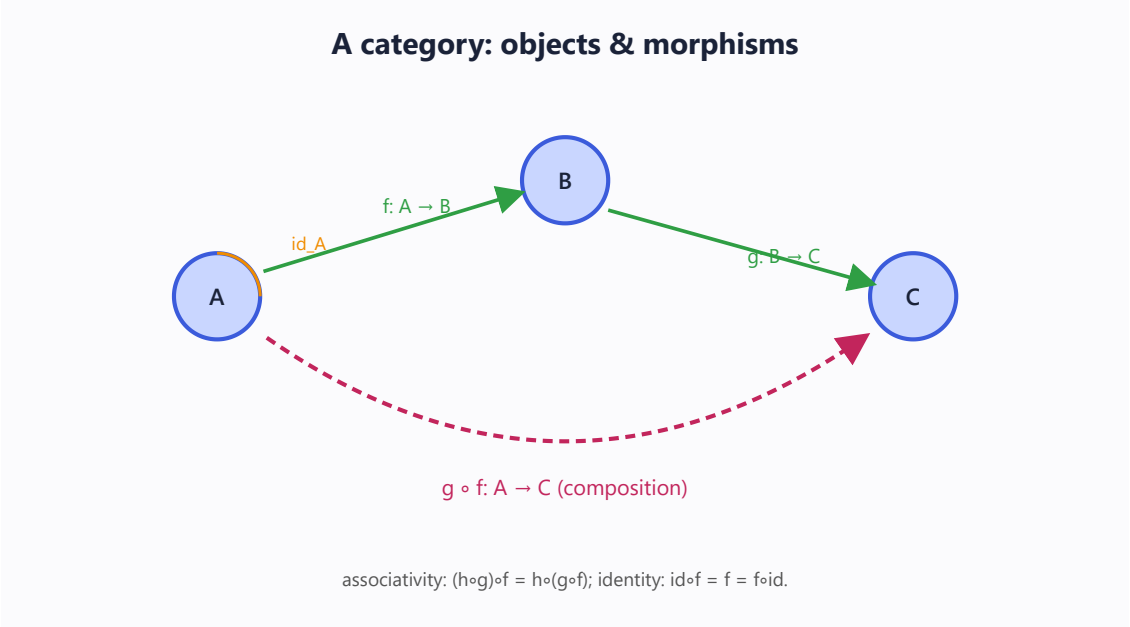
$$F(g \circ f) = F(g) \circ F(f), \qquad F(\mathrm{id}_A) = \mathrm{id}_{F(A)} \tag{2.47}$$

جدول الرموز

الرمز	المعنى
كائن	عقدة (مثل فضاء متّجهيّ أو مجموعة)
سهم	تحويل بين كائنين
مُقوّب	رسم بين فئتين يحفظ البنية

الرسم

<figure> الشكل 1.47: كائنات A, B, C وسهام f, g وتركيبها $g \circ f$، مع هويّة id_A</figcaption>.



شكل ١.٤٧: *
الفئة والتركيب

</figure>

البرهان

الخطوة 1 (تعريف الفئة): بيانات (كائنات، سهام، تركيب، هويّات) مع بديهيّتين. ■

الخطوة 2 (الترابطيّة): تركيب ثلاثة سهام لا يعتمد على التجميع. ■

الخطوة 3 (المُقوّب): رسمٌ يحفظ التركيب والهويّة ⇒ يُنقل البنية بين الفئات. ■

خمسة عشر مثالاً محلولاً

مثال (1-2.47): فئة المجموعات المعطيات: **Set**: الكائنات مجموعات، والسهام دوالّ. المطلوب: التحقّق من البديهيّات. الحل: الخطوة 1: تركيب الدوالّ ترابطيّ؛ والدالّة الهويّة محايدة. النتيجة: **Set** فئة. الربط بالذكاء الاصطناعي: أساس الأمثلة.

مثال (2-2.47): فئة الفضاءات المتّجهيّة المعطيات: **Vect**: كائنات فضاءات، سهام تحويلات خطّيّة. المطلوب: التركيب. الحل: الخطوة 1: تركيب تحويلين خطّيّين خطّيّ؛ ترابطيّ. النتيجة: فئة صالحة. الربط بالذكاء الاصطناعي: موترات الأوزان.

مثال (47.2-3): عدد السهام المعطيات: فئة بكائنين A, B وسهمين $f : A \to B$ و$g : B \to A$ مع الهويّات. المطلوب: كم سهمًا من A إلى A؟ الحل: الخطوة 1: id_A و$f \circ g$ (لو لم يتطابقا) $\Rightarrow$ 2. النتيجة: 2. الربط بالذكاء الاصطناعي: عدّ التحويلات.

مثال (47.2-4): ترابطيّة المعطيات: $f : A \to B, g : B \to C, h : C \to D$. المطلوب: $(h \circ g) \circ f$ مقابل $h \circ (g \circ f)$. الحل: الخطوة 1: متساويان ببديهيّة الفئة. النتيجة: متساويان. الربط بالذكاء الاصطناعي: ترتيب الطبقات.

مثال (47.2-5): هويّة المعطيات: $f : A \to B$. المطلوب: $f \circ \mathrm{id}_B$. الحل: الخطوة 1: $f =$ (حياديّة الهويّة). النتيجة: f. الربط بالذكاء الاصطناعي: طبقة هويّة لا تؤثّر.

مثال (47.2-6): مُقوّب قوّة مجموعة المعطيات: $F(X) = X \times X$ على **Set**؛ $F(f)(x, y) = (f(x), f(y))$. المطلوب: هل يحفظ التركيب؟ الحل: الخطوة 1: $F(g \circ f)(x, y) = ((g \circ f)(x), (g \circ f)(y)) = (g(f(x)), g(f(y))) = F(g)(F(f)(x, y))$. النتيجة: نعم. الربط بالذكاء الاصطناعي: تكرار الميزات.

مثال (47.2-7): مُقوّب الهويّة المعطيات: $F(A) = A, F(f) = f$. المطلوب: هل مُقوّب؟ الحل: الخطوة 1: يحفظ التركيب والهويّة بوضوح $\Rightarrow$ نعم. النتيجة: نعم. الربط بالذكاء الاصطناعي: مرور بلا تغيير.

مثال (47.2-8): مُقوّب ثابت المعطيات: $F(A) = K$ (ثابت)، $F(f) = \mathrm{id}_K$. المطلوب: التحقّق. الحل: الخطوة 1: $F(g \circ f) = \mathrm{id}_K = \mathrm{id}_K \circ \mathrm{id}_K = F(g) \circ F(f)$ $\Rightarrow$ نعم. النتيجة: مُقوّب. الربط بالذكاء الاصطناعي: تجاهل المدخل.

مثال (47.2-9): مُقوّب داخليّ (endofunctor) المعطيات: $F : \mathcal{C} \to \mathcal{C}$ (نفس الفئة). المطلوب: التسمية. الحل: الخطوة 1: مُقوّب داخليّ. (endofunctor) النتيجة: داخليّ. الربط بالذكاء الاصطناعي: تحويل داخل النموذج.

مثال (47.2-10): تركيب مُقوّبين المعطيات: $F : \mathcal{C} \to \mathcal{D}$، $G : \mathcal{D} \to \mathcal{E}$. المطلوب: $G \circ F$. الحل: الخطوة 1: مُقوّب من $\mathcal{C}$ إلى $\mathcal{E}$ (يحفظ التركيب). النتيجة: مُقوّب مركّب. الربط بالذكاء الاصطناعي: تركيب نماذج.

مثال (47.2-11): فئة مضادّة (تباين) المعطيات: $F : \mathcal{C}^{op} \to \mathcal{D}$. المطلوب: ماذا يعني؟ الحل: الخطوة 1: يعكس اتجاه السهام (مُقوّب مضادّ التباين). النتيجة: يعكس الاتجاه. الربط بالذكاء الاصطناعي: تمييز التدرّج العكسيّ.

مثال (47.2-12): الفئة المضادة $\mathcal{C}^{op}$ المعطيات: نفس الكائنات، والسهام معكوسة. المطلوب: كم سهمًا من B إلى A في $\mathcal{C}^{op}$ لو كان في $\mathcal{C}$ سهمان من A إلى B؟ الحل: الخطوة 1: 2 (معكوسة). النتيجة: 2. الربط بالذكاء الاصطناعي: عكس التدفّق.

مثال (47.2-13): فئة جدائيّة المعطيات: $\mathcal{C} \times \mathcal{D}$: كائنات (C, D). المطلوب: تركيب السهام. الحل: الخطوة 1: $(g, g') \circ (f, f') = (g \circ f, g' \circ f')$ مكوّنةً بمكوّنة. النتيجة: مكوّنةً بمكوّنة. الربط بالذكاء الاصطناعي: أزواج متوازية.

مثال (47.2-14): مُقوّب أمين وكامل المعطيات: F يحقن/يملأ Hom-مجموعات. المطلوب: المصطلحات. الحل: الخطوة 1: أمين (faitfhul) = يحقن، كامل (full) = يملأ. النتيجة: تمييز الدقّة. الربط بالذكاء الاصطناعي: تعبير التمثيل.

مثال (47.2-15): خلاصة المعطيات: فئة بأيّ كائنات. المطلوب: شرط الصحّة. الحل: الخطوة 1: ترابطيّة التركيب + حياديّة الهويّة. النتيجة: بديهيّتان فقط. الربط بالذكاء الاصطناعي: اقتصاد البديهيّات.

أخطاء شائعة

- **نسيان الترابطيّة:** تركيب ثلاثة سهام بلا ترابط ليس فئة.
- **الخلط بين الكائن والسهم:** الكائن عقدة، والسهم تحويل.
- **ظنّ أنّ كلّ رسم مُقوّب:** يجب حفظ التركيب والهويّة.
- **الخلط بين $\mathcal{C}^{op}$ والفئة العكسيّة:** نفس الكائنات، سهام معكوسة فقط.

- **نسيان أنّ** $g \circ f$ **يُقرأ «**f **ثمّ** g**»:** الترتيب مهمّ.

صياغة رسمية: تحويل طبيعيّ $\alpha : F \Rightarrow G$ عائلةُ سهام $\alpha_A : F(A) \to G(A)$ تحقّق لكلّ $h : A \to B$:

$$G(h) \circ \alpha_A = \alpha_B \circ F(h) \qquad \text{(مربّع الطبيعيّة)} \tag{3.47}$$

والخصيصة العالميّة (كالجداء $A \times B$): أيّ زوج $f : X \to A$، $g : X \to B$ يمرّ وحيداً عبر $\langle f, g \rangle : X \to A \times B$. والمرافقة $F \dashv G$:

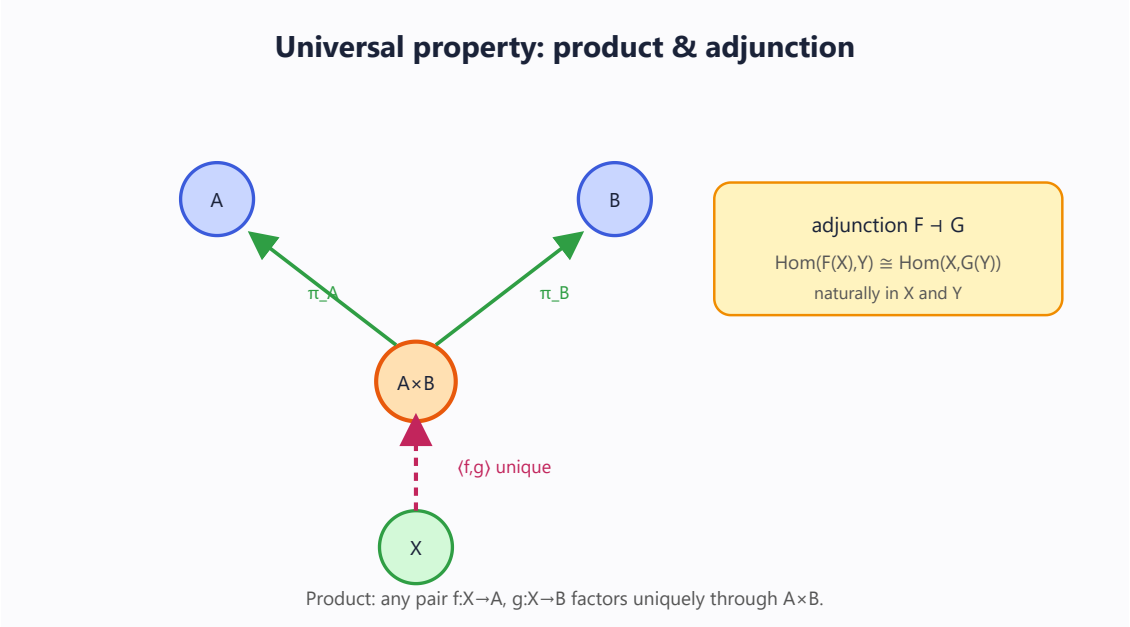
$$\mathrm{Hom}_{\mathcal{D}}(F(X), Y) \;\cong\; \mathrm{Hom}_{\mathcal{C}}(X, G(Y)) \qquad X, Y \text{ طبيعيّاً في} \tag{4.47}$$

جدول الرموز

الرمز	المعنى
$\alpha : F \Rightarrow G$	تحويل طبيعيّ بين مُقوّمين
π_A, π_B	إسقاطات الجداء
$F \dashv G$	مرافقة (adjunction)
η, ε	وحدة المرافقة ومُضادّها

الرسم

<figure> الشكل<figcaption> 2.47: الجداء $A \times B$ بإسقاطاته، وأيّ زوج يمرّ وحيداً عبره؛ والمرافقة على



شكل ٢.٤٧: *
الخصائص العالميّة

اليمين.</figcaption> </figure>

البرهان

الخطوة 1 (الطبيعيّة): لكلّ سهم h، المربّع المكوّن من $\alpha_A, \alpha_B, F(h), G(h)$ يتبادل. ■

الخطوة 2 (الجداء): وحيدانية الوسيط $\langle f, g \rangle$ مميّزة $A \times B \Rightarrow$ معرّف حتى تشاكُل وحيد. ■

الخطوة 3 (المرافقة): تطابق طبيعيّ بين مجموعتي الـHom يعادل وجود η, ε بمعادلتَي المثلّث. ■

خمسة عشر مثالاً محلولاً

مثال (47.3-1): مربّع طبيعيّ المعطيات: $h : c \to c'$، تحويل $\alpha : F \Rightarrow G$. المطلوب: شرط الطبيعيّة. الحل: الخطوة 1: $G(h) \circ \alpha_c = \alpha_{c'} \circ F(h)$. النتيجة: المربّع يتبادل. الربط بالذكاء الاصطناعي: اتساق التمثيل.

مثال (47.3-2): تحويل غير طبيعيّ المعطيات: عائلة سهام لا تحقّق (47.3). المطلوب: الحكم. الحل: الخطوة 1: ليس تحويلاً طبيعيّاً (المربّع لا يتبادل). النتيجة: مرفوض. الربط بالذكاء الاصطناعي: يحتاج تحقّقاً.

مثال (47.3-3): الجداء في **Set** المعطيات: $A \times B$ مع π_A, π_B. المطلوب: التحقّق من العالميّة. الحل: الخطوة 1: لكلّ f, g وX، $\langle f, g \rangle(x) = (f(x), g(x))$ وحيد. النتيجة: عالميّة محقّقة. الربط بالذكاء الاصطناعي: دمج الميزات.

مثال (47.3-4): وحيدانية الوسيط المعطيات: $f : X \to A, g : X \to B$. المطلوب: عدد الوسطاء الممكنة. الحل: الخطوة 1: واحد فقط (يُحدَّد بالإسقاطات). النتيجة: 1. الربط بالذكاء الاصطناعي: تحدّد البنية.

مثال (47.3-5): الجداء حتى تشاكُل المعطيات: جداءان P, P' بنفس الإسقاطات. المطلوب: العلاقة. الحل: الخطوة 1: يوجد تشاكُل وحيد $P \cong P'$ (بالعالميّة). النتيجة: متشاكلان. الربط بالذكاء الاصطناعي: تعريف وحيد.

مثال (47.3-6): المرافقة حرّ/ناسي المعطيات: F : Mon→Set (أحادي حرّ)، U ناسي. المطلوب: صيغة المرافقة. الحل: الخطوة 1: $\mathrm{Hom}_{Mon}(F(S), M) \cong \mathrm{Hom}_{Set}(S, U(M))$. النتيجة: $F \dashv U$. الربط بالذكاء الاصطناعي: بنية وحرّية.

مثال (47.3-7): وحيدانية المرافق المعطيات: $F \dashv G$ و$F \dashv G'$. المطلوب: العلاقة بين G, G'. الحل: الخطوة 1: المرافق الأيمن وحيد حتى تشاكُل طبيعيّ. النتيجة: $G \cong G'$. الربط بالذكاء الاصطناعي: تعريف وحيد.

مثال (47.3-8): وحدة المرافقة المعطيات: $\eta_X : X \to G(F(X))$. المطلوب: دورها. الحل: الخطوة 1: تُضمّن X في الصورة تحت المرافق. النتيجة: وحدة. الربط بالذكاء الاصطناعي: تضمين الميزات.

مثال (47.3-9): المُضادّ المعطيات: $\varepsilon_Y : F(G(Y)) \to Y$. المطلوب: دورها. الحل: الخطوة 1: تُقيّم (تطبّق) البنية الحرّة. النتيجة: المُضادّ. الربط بالذكاء الاصطناعي: حساب التوقّع.

مثال (47.3-10): معادلتا المثلّث المعطيات: $F \dashv G$ بـη, ε. المطلوب: الشرط. الحل: الخطوة 1: $\varepsilon_{F(X)} \circ F(\eta_X) = \mathrm{id}$ و$G(\varepsilon_Y) \circ \eta_{G(Y)} = \mathrm{id}$. النتيجة: معادلتان. الربط بالذكاء الاصطناعي: اتساق الذهاب والإياب.

مثال (47.3-11): التحويل الطبيعيّ كمربّع المعطيات: فئتان وحيدتا السهم. المطلوب: كم شرطاً نتحقّق؟ الحل: الخطوة 1: شرط واحد لكلّ سهم (هنا 1). النتيجة: 1. الربط بالذكاء الاصطناعي: عبء التحقّق.

مثال (47.3-12): الجداء الفارغ (نهاية) المعطيات: الكائن النهائيّ 1: سهم وحيد من كلّ كائن. المطلوب: التسمية. الحل: الخطوة 1: هذا «الجداء الفارغ» (نهاية فارغة). النتيجة: كائن نهائيّ. الربط بالذكاء الاصطناعي: ثابت وحيد.

مثال (47.3-13): المجموع المشترك (coproduct) المعطيات: $A + B$ بحقنَين. المطلوب: الخصيصة. الحل: الخطوة 1: عكس الجداء (خارجٌ من $A + B$)؛ وحيد أيضاً. النتيجة: ثنائيّ وحيد. الربط بالذكاء الاصطناعي: اتحاد الأصناف.

مثال (47.3-14): فائدة العالميّة عمليّاً المعطيات: نريد تعريف بنية. المطلوب: المنهج. الحل: الخطوة 1: نُعرّفها بخصيصتها العالميّة لا بتركيبها الداخليّ. النتيجة: تعريف نظيف. الربط بالذكاء الاصطناعي: تصميم الواجهات.

مثال (15-3.47): خلاصة المعطيات: خاصيصة عالميّة. المطلوب: ماذا تمنح؟ الحل: الخطوة 1: تعريفاً وحيداً حتى تشاكُل، وبنيةً قابلة للتركيب. النتيجة: أساس نظريّ. الربط بالذكاء الاصطناعي: قابلية التوسّع.

أخطاء شائعة

- **نسيان شرط الطبيعيّة:** عائلة سهام بلا تبادل المربّع ليست تحويلاً.
- **الخلط بين الجداء والمجموع المشترك:** الأوّل «إلى» والثاني «من».
- **ظنّ أنّ المرافق وحيد تماماً:** هو وحيد حتى تشاكُل طبيعيّ.
- **إغفال وحيدانية الوسيط:** تميّز العالميّة.
- **الخلط بين η وε:** الأوّل يدخل، والثاني يخرج.

صياغة رسمية: الفئة المونويّدة خماسيّة $(\mathcal{C}, \otimes, I, \alpha, \lambda, \rho)$ بجداء مونيّد $\otimes$ ووحدة I وتشاكلات طبيعيّة:

$$\alpha_{A,B,C} : (A \otimes B) \otimes C \xrightarrow{\cong} A \otimes (B \otimes C), \qquad \lambda_A : I \otimes A \cong A, \quad \rho_A : A \otimes I \cong A \tag{5.47}$$

تحقّق بديهيّة الخماسيّ (pentagon) وبديهيّة المثلّث.

جدول الرموز

الرمز	المعنى
$\otimes$	الجداء المونيّد (متوازٍ)
I	كائن الوحدة
α	المُجمّع (associator)
رسم شريطيّ	أسلاك = كائنات، صناديق = سهام

الرسم

<figure> الشكل<figcaption> 3.47: السلكان المتوازيان = $\otimes$ (متوازٍ)؛ والصناديق المتسلسلة = التركيب.</figcaption>
</figure>

البرهان

الخطوة 1 (ثنائيّة المُقوّب): $\otimes : \mathcal{C} \times \mathcal{C} \to \mathcal{C}$ مُقوّب في المتغيّرين معاً. ■

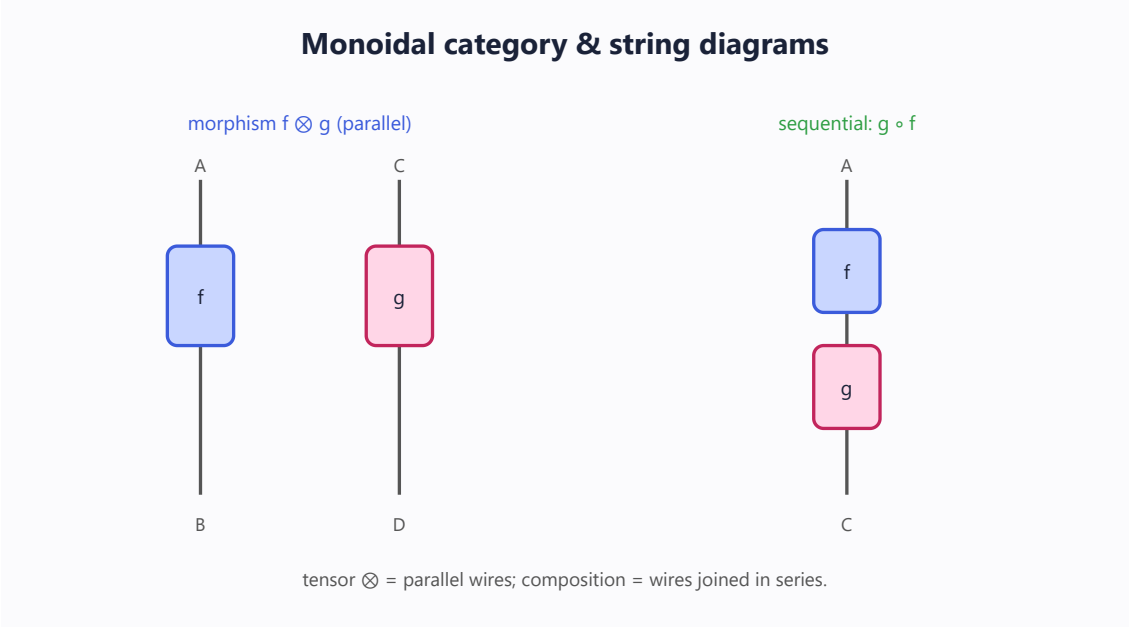
الخطوة 2 (التشاكلات الطبيعيّة): α, λ, ρ تحويلات طبيعيّة (مربّعاتها تتبادل). ■

الخطوة 3 (التماسك): بديهيّتا الخماسيّ والمثلّث تضمنان أنّ كلّ مخططات إعادة التجميع متكافئة (نظريّة التماسك لِماك لين). ■

خمسة عشر مثالاً محلولاً

مثال (1-4.47): جداء المجموعات المعطيات: $(\mathbf{Set}, \times, \{*\})$؛ $\|A\| = 3, \|B\| = 4$. المطلوب: $|A \times B|$. الحل: الخطوة 1: $3 \times 4 = 12$. النتيجة: 12. الربط بالذكاء الاصطناعي: دمج الميزات.

مثال (2-4.47): وحدة الجداء المعطيات: $I = \{*\}$ (مفردة). المطلوب: $|A \times I|$. الحل: الخطوة 1: $|A| = 3 \Rightarrow 3 \times 1 = 3$ محايد. النتيجة: 3. الربط بالذكاء الاصطناعي: بلا تأثير.



شكل ٣٠٤٧: *
مونيّد وشريطيّ

مثال (3-4.47): مجموع منفصل المعطيات: $(\varnothing, +,)$ **Set**؛ $|A| = 3, |B| = 4$. المطلوب: $|A + B|$. الحل: الخطوة 1: $3 + 4 = 7$ (اتّحاد منفصل). النتيجة: 7. الربط بالذكاء الاصطناعي: أصناف متعدّدة.

مثال (4-4.47): وحدة المجموع المعطيات: $I = \varnothing$. المطلوب: $|A + \varnothing|$. الحل: الخطوة 1: $\varnothing \Rightarrow 3 + 0 = 3$ محايد للمجموع. النتيجة: 3. الربط بالذكاء الاصطناعي: كائن ابتدائيّ.

مثال (5-4.47): جداء موتري المعطيات: $(\otimes_k, k\textbf{Vect})$؛ $\dim A = 3, \dim B = 4$. المطلوب: $\dim(A \otimes B)$. الحل: الخطوة 1: $3 \times 4 = 12$. النتيجة: 12. الربط بالذكاء الاصطناعي: أوزان الطبقة.

مثال (6-4.47): وحدة المتّجهات المعطيات: $I = k$ (بُعد 1). المطلوب: $\dim(A \otimes k)$. الحل: الخطوة 1: $3 \times 1 = 3 \Rightarrow k$ وحدة. النتيجة: 3. الربط بالذكاء الاصطناعي: مقياس ثابت.

مثال (7-4.47): ترابطيّة المعطيات: $(A \otimes B) \otimes C$ مقابل $A \otimes (B \otimes C)$. المطلوب: العلاقة. الحل: الخطوة 1: ليسا متساويين بل متشاكلين طبيعيّاً عبر α. النتيجة: متشاكلان لا متساويان. الربط بالذكاء الاصطناعي: إعادة التجميع.

مثال (8-4.47): رسم شريطيّ متوازٍ المعطيات: $f : A \to B$ و $g : C \to D$. المطلوب: الرسم. الحل: الخطوة 1: سلكان متوازيان بصندوقين = $f \otimes g$. النتيجة: توازٍ. الربط بالذكاء الاصطناعي: فروع متوازية.

مثال (9-4.47): رسم متسلسل المعطيات: $f : A \to B, g : B \to C$. المطلوب: الرسم. الحل: الخطوة 1: صندوقان على سلك واحد = $g \circ f$. النتيجة: تسلسل. الربط بالذكاء الاصطناعي: طبقات متتالية.

مثال (10-4.47): نظريّة التماسك المعطيات: مخططات إعادة تجميع متعدّدة. المطلوب: ماذا تضمن؟ الحل: الخطوة 1: كلّها متكافئة $\Rightarrow$ لا لبس في الحساب الشريطيّ. النتيجة: حساب آمن. الربط بالذكاء الاصطناعي: موثوقيّة.

مثال (11-4.47): فئة متماثلة (symmetric) المعطيات: تشاكل تبادليّ $\sigma_{A,B} : A \otimes B \cong B \otimes A$. المطلوب: الاسم. الحل: الخطوة 1: فئة مونيّدة متماثلة (symmetric monoidal). النتيجة: متماثلة. الربط بالذكاء الاصطناعي: تبديل القنوات.

مثال (12-4.47): مونيّد مُغلق المعطيات: كائن داخليّ $[A, B]$ (Hom داخليّ). المطلوب: الفائدة. الحل: الخطوة 1: يسمح بتمثيل السهام ككائنات داخل الفئة. النتيجة: إغلاق. الربط بالذكاء الاصطناعي: دالّة داخل النموذج.

مثال (13-4.47): مقياس الرسوم المعطيات: 3 صناديق متوازية. المطلوب: كم سلكاً؟ الحل: الخطوة 1: 3 أسلاك (واحد لكلّ صندوق). النتيجة: 3. الربط بالذكاء الاصطناعي: بنية مرئيّة.

مثال (14-4.47): مونيّد في **Rel** المعطيات: علاقات مع $\times$. المطلوب: هل مونيّد؟ الحل: الخطوة 1: نعم؛ جداء ديكارتيّ مع وحدة مفردة. النتيجة: مونيّد. الربط بالذكاء الاصطناعي: رسوم بيانية.

مثال (15-4.47): خلاصة المعطيات: فئة مونيّدة. المطلوب: ماذا تضيف؟ الحل: الخطوة 1: لغةً للتركيب المتوازي ($\otimes$) والمتسلسل ($\circ$) معاً. النتيجة: أساس التركيبية. الربط بالذكاء الاصطناعي: هندسة النماذج.

أخطاء شائعة

- **ظنّ أنّ $(A \otimes B) \otimes C = A \otimes (B \otimes C)$:** متشاكلان عبر α لا متساويان.
- **نسيان أنّ α, λ, ρ تشاكلات طبيعيّة:** وليست مجرّد دوالّ.
- **الخلط بين $\otimes$ و$\circ$:** الأوّل متوازٍ، والثاني متسلسل.
- **إغفال بديهيّتي الخماسيّ والمثلّث:** بدونهما لا تماسك.
- **ظنّ كلّ فئة مونيّدة متماثلة:** التماثل شرط إضافيّ (σ).

صياغة رسمية: موناد على فئة $\mathcal{C}$ ثلاثيّة (T, η, μ) بمُقوّب داخليّ $T : \mathcal{C} \to \mathcal{C}$ وتحويلين طبيعيّين:

$$\eta : \mathrm{Id}_{\mathcal{C}} \Rightarrow T \ (\text{وحدة}), \qquad \mu : T^2 \Rightarrow T \ (\text{ضرب}) \tag{6.47}$$

تحقّق قوانين الترابط والوحدة:

$$\mu \circ T\mu = \mu \circ \mu T, \qquad \mu \circ T\eta = \mathrm{id}_T = \mu \circ \eta T \tag{7.47}$$

جدول الرموز

الرمز	المعنى
T	مُقوّب داخليّ (يغلّف القيم)
$\eta_A : A \to T(A)$	يُدخل قيمة في الغلاف
$\mu_A : T^2(A) \to T(A)$	يُسطّح الغلاف المزدوج
Kleisli	فئة السهام $A \to T(B)$

الرسم

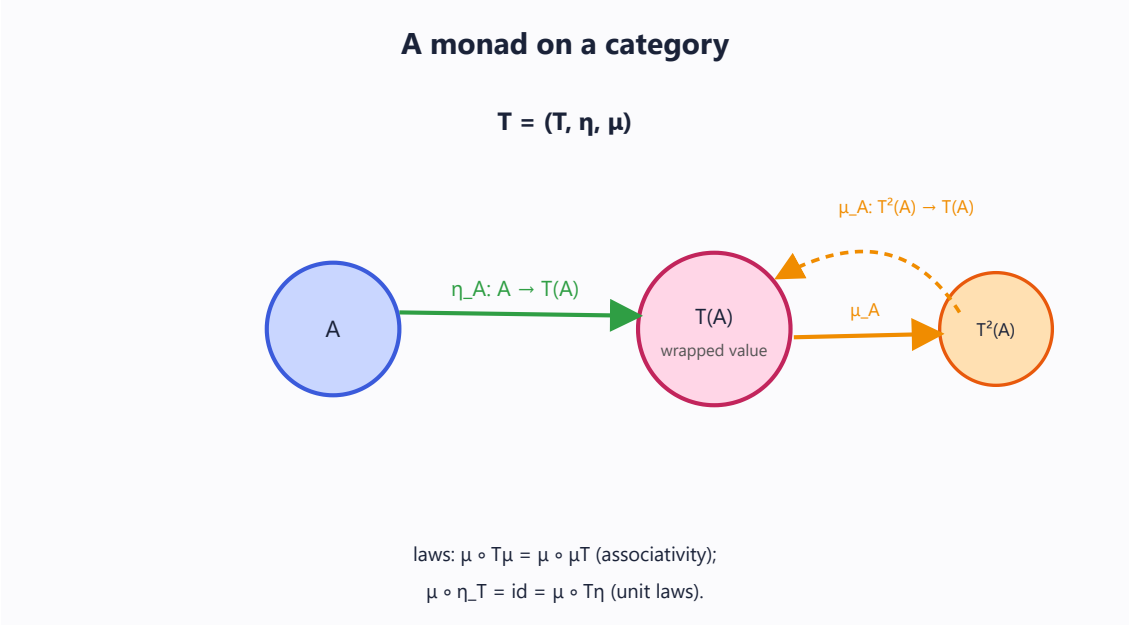
<figure> الشكل 4.47: A يُغلَّف بـ$T(A)$ عبر η؛ والغلاف المزدوج $T^2(A)$ يُسطَّح بـμ. </figcaption></figure>

البرهان

الخطوة 1 (المُقوّب الداخليّ): T يرسل $\mathcal{C}$ إلى نفسها ويحفظ التركيب. ■

الخطوة 2 (الطبيعيّة): η, μ تحويلات طبيعيّة $\Rightarrow$ مربّعاتها تتبادل مع كلّ سهم. ■

الخطوة 3 (القوانين): (7.47) تضمن أنّ تسلسل «الإدخال/التسطيح» لا يعتمد على الترتيب. ■



شكل ٤٠٤٧: *
الموناد

خمسة عشر مثالاً محلولاً

مثال (5.47-1): موناد القائمة المعطيات: $T(X) =$ قائمة عناصر X، $X = \{1, 2\}$. المطلوب: $\eta(1)$. الحل: الخطوة 1: القائمة المفردة $[1]$. النتيجة: $[1]$. الربط بالذكاء الاصطناعي: دفعات (batch).

مثال (5.47-2): تسطيح القائمة المعطيات: $[[1], [2, 3]] \in T^2(X)$. المطلوب: μ. الحل: الخطوة 1: ربط القوائم $\Rightarrow [1, 2, 3]$. النتيجة: $[1, 2, 3]$. الربط بالذكاء الاصطناعي: دمج النتائج.

مثال (5.47-3): موناد الاختياريّ المعطيات: $T(X) = X + \{\text{None}\}$، $|X| = 3$. المطلوب: $|T(X)|$. الحل: الخطوة 1: $3 + 1 = 4$. النتيجة: 4. الربط بالذكاء الاصطناعي: قيمة أو غياب.

مثال (5.47-4): تسطيح الاحتمال المعطيات: Just(Just 5). المطلوب: μ. الحل: الخطوة 1: Just 5 (تُسطَّح طبقة). النتيجة: Just 5. الربط بالذكاء الاصطناعي: تبسيط الاختياريّ.

مثال (5.47-5): موناد المجموعة الجزئيّة المعطيات: $T(X) = \mathcal{P}(X)$، $|X| = 3$. المطلوب: $|T(X)|$. الحل: الخطوة 1: $2^3 = 8$. النتيجة: 8. الربط بالذكاء الاصطناعي: فضاء الاختيارات.

مثال (5.47-6): تسطيح المجموعة المعطيات: $S = \{\{1, 2\}, \{3\}\} \in T^2(X)$. المطلوب: $\mu(S)$. الحل: الخطوة 1: اتحاد $\Rightarrow \{1, 2, 3\}$. النتيجة: $\{1, 2, 3\}$. الربط بالذكاء الاصطناعي: دمج المجموعات.

مثال (5.47-7): موناد التوزيع المعطيات: $T(X) = \Delta(X)$ (توزيعات احتماليّة)، $\eta(x) = \delta_x$. المطلوب: معنى η. الحل: الخطوة 1: يُحوّل القيمة إلى توزيع ديراك المركّز عليها. النتيجة: δ_x. الربط بالذكاء الاصطناعي: يقين ابتدائيّ.

مثال (5.47-8): تسطيح التوزيع المعطيات: توزيع على توزيعات: $0.5\,\delta_{\delta_1} + 0.5\,\delta_{\delta_0}$. المطلوب: μ. الحل: الخطوة 1: المزيج $\Rightarrow 0.5\,\delta_0 + 0.5\,\delta_1$. النتيجة: مزيج نصف/نصف. الربط بالذكاء الاصطناعي: تجميع احتماليّ.

مثال (5.47-9): قانون الوحدة المعطيات: $x \in T(A)$ عبر η_A، طبّق $\mu_A \circ T(\eta_A)$. المطلوب: النتيجة. الحل: الخطوة 1: $\mu(T(\eta(x))) = \mu([\text{غلاف}]) = x \Rightarrow$ يعود أصله. النتيجة: x. الربط بالذكاء الاصطناعي: لا فقدان.

مثال (5.47-10): قانون الترابط المعطيات: ثلاث طبقات T^3. المطلوب: هل ترتيب التسطيح يهمّ؟ الحل: الخطوة 1: لا، $\mu \circ T\mu = \mu \circ \mu T \Rightarrow$ نفس النتيجة. النتيجة: لا يهمّ. الربط بالذكاء الاصطناعي: حساب متسق.

مثال (11-5.47): فئة Kleisli المعطيات: سهام $A \to T(B)$. المطلوب: كيف تُركّب؟ الحل: الخطوة 1: $g \bullet f = \mu \circ T(g) \circ f$ (تركيب كلايسلي). النتيجة: تركيب مُغلَّف. الربط بالذكاء الاصطناعي: تسلسل تأثيرات.

مثال (12-5.47): موناد الحالة المعطيات: $T(X) = (S \to X \times S)$. المطلوب: ماذا يغلّف؟ الحل: الخطوة 1: حسابًا يقرأ حالةً ويعيد قيمةً وحالةً جديدة. النتيجة: حساب ذو حالة. الربط بالذكاء الاصطناعي: ذاكرة النموذج.

مثال (13-5.47): موناد الكاتب المعطيات: $T(X) = X \times W$ (W مونيّد سجلّ). المطلوب: الفائدة. الحل: الخطوة 1: يُرفق الحساب بسجلّ (مثل سجلّ التدرّجات). النتيجة: تتبّع الحساب. الربط بالذكاء الاصطناعي: تسجيل التدرّج.

مثال (14-5.47): الموناد والآثار الجانبيّة المعطيات: كود فيه عشوائيّة أو إدخال/إخراج. المطلوب: دور الموناد. الحل: الخطوة 1: يُغلّف الآثار في T فتبقى الدوالّ نقيّة رياضيّاً. النتيجة: عزل الآثار. الربط بالذكاء الاصطناعي: نماذج قابلة للاختبار.

مثال (15-5.47): خلاصة المعطيات: أيّ موناد. المطلوب: ما يوحّده؟ الحل: الخطوة 1: نمط «تغليف + تسطيح» يظهر في قوائم، احتمالات، حالات، وسجلّات. النتيجة: نمط كلّيّ. الربط بالذكاء الاصطناعي: تجريد قويّ.

أخطاء شائعة

- **الخلط بين η وμ:** الأوّل يُدخل، والثاني يُسطّح.
- **نسيان أنّ T مُقوّب داخليّ:** يجب أن يحفظ التركيب على نفس الفئة.
- **ظنّ أنّ القوانين اختياريّة:** بدونها لا موناد صحيح.
- **الخلط بين T^2 و$T \circ T$ بلا طبيعيّة:** μ تحويل طبيعيّ لا دالّة اعتباطيّة.
- **إغفال فئة كلايسلي:** وهي المكان الطبيعيّ لتركيب السهام المُغلَّفة.

صياغة رسمية: عدسة (lens) من S إلى A زوجُ (get, set):

$$get : S \to A, \qquad set : S \times A \to S \tag{8.47}$$

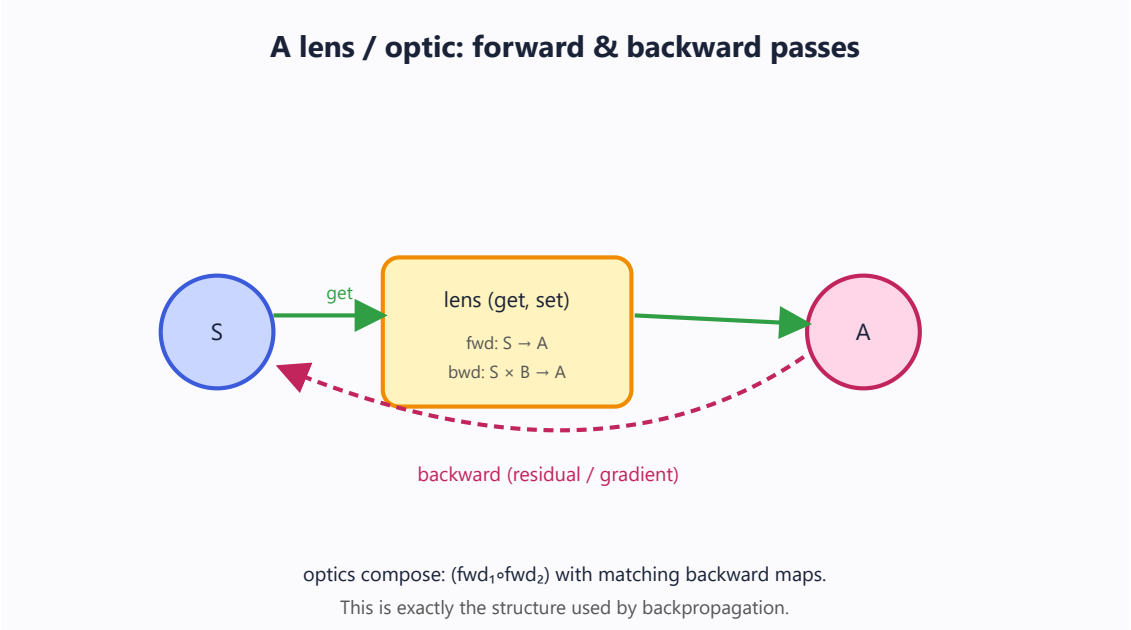
تحقّق قوانين العدسة: $get(set(s,a)) = a$، و$set(s, get(s)) = s$، و$set(set(s,a),a') = set(s,a')$. والبصريّة (optic) تعميمٌ يحمل تمريرةً أماميّةً وأخرى خلفيّة.

جدول الرموز

الرمز	المعنى
get	قراءة جزء من الحالة
set	تحديث الجزء مع بقاء الباقي
بصريّة	أماميّ + خلفيّ (تمريرتان)
قانون العدسة	اتّساق القراءة/التحديث

الرسم

<figure> الشكل<figcaption> 5.47: العدسة تمرّر البيانات أماماً (get) وتعيد التحديث خلفاً ؛(set) وهذا عينُ بنية الانتشار العكسيّ.</figcaption> </figure>



شكل ٥.٤٧: *
العدسة والبصريّة

البرهان

الخطوة 1 (القراءة والتحديث): get يستخرج الجزء، وset يعيد بناء الكلّ منه. ■

الخطوة 2 (القوانين): الثلاثة تضمن أنّ القراءة بعد التحديث تُطابق، وأنّ التحديث بلا تغيير لا يُبدّل، وأنّ التحديثات تتراصّ. ■

الخطوة 3 (التركيب): عدستان تُركّبان، get بالتركيب وset بتمرير التحديث للداخل $\Rightarrow$ عدسة جديدة. ■

خمسة عشر مثالاً محلولاً

مثال (1-6.47): عدسة على زوج المعطيات: $S = (x, y)$ إحداثيّتان، $get((x, y)) = x$. المطلوب: $set((x, y), x')$.
الحل: الخطوة 1: (x', y) (نبدّل الأولى فقط). النتيجة: (x', y). الربط بالذكاء الاصطناعي: تحديث ميزة.

مثال (2-6.47): قانون القراءة بعد التحديث المعطيات: من (1-6.47)، $(5, 7)$. المطلوب: $set((3, 7), 5)$.
الحل: الخطوة 1: get بعده $\Rightarrow$ $get((5, 7)) = 5$ يطابق المُدخَل. النتيجة: 5. الربط بالذكاء الاصطناعي: اتساق مضمون.

مثال (3-6.47): تحديث بلا تغيير المعطيات: $s = (3, 7)$، $get(s) = 3$. المطلوب: $set(s, 3)$.
الحل: الخطوة 1: يعيد $(3, 7)$ نفسه. النتيجة: $(3, 7)$. الربط بالذكاء الاصطناعي: عدم تدمير الحالة.

مثال (4-6.47): تراصّ التحديثات المعطيات: $set((3, 7), 5) = (5, 7)$ ثمّ $set(\cdot, 9)$. المطلوب: النتيجة. الحل:
الخطوة 1: $set((5, 7), 9) = set((3, 7), 9) = (9, 7)$ مباشرةً. النتيجة: $(9, 7)$. الربط بالذكاء الاصطناعي: آخر تحديث يسود.

مثال (5-6.47): تركيب عدستين المعطيات: $l_1 : S \to A$ و$l_2 : A \to B$. المطلوب: get المركّبة. الحل: الخطوة 1: $get_{12} = get_2 \circ get_1$. النتيجة: تركيب القراءات. الربط بالذكاء الاصطناعي: وصول عميق.

مثال (6-6.47): تركيب التحديث المعطيات: من (5-6.47). المطلوب: $set_{12}(s, b)$. الحل: الخطوة 1: $set_1(s,\ set_2(get_1(s), b))$ (يُمرَّر للداخل). النتيجة: تحديث متداخل. الربط بالذكاء الاصطناعي: تحديث هرميّ.

مثال (7-6.47): عدسة على سجلّ المعطيات: $S = \{name, age\}$، $get =$ العمر. المطلوب: set للعمر 30. الحل:

الخطوة 1: يُحدَّث العمر ويبقى الاسم. النتيجة: سجلّ مُحدَّث. الربط بالذكاء الاصطناعي: حقول النموذج.

مثال (6.47-8): بصريّة عامّة المعطيات: تمريرة أماميّة $f : S \to A$ وخلفيّة $r : S \times B \to A$. المطلوب: أين تظهر؟ الحل: الخطوة 1: في التعلّم: الأماميّة = التنبّؤ، الخلفيّة = التدرّج. النتيجة: بنية التعلّم. الربط بالذكاء الاصطناعي: جوهر (8.47).

مثال (6.47-9): حساب القوانين المعطيات: عدسة لا تحقّق $get(set(s, a)) = a$. المطلوب: الحكم. الحل: الخطوة 1: ليست عدسة صالحة (فقدان). النتيجة: مرفوضة. الربط بالذكاء الاصطناعي: تصميم صحيح.

مثال (6.47-10): عدسة وقيم ابتدائيّة المعطيات: S بـ10 حقول. المطلوب: كم عدسة إسقاط؟ الحل: الخطوة 1: 10 (واحدة لكلّ حقل). النتيجة: 10. الربط بالذكاء الاصطناعي: وصول منظّم.

مثال (6.47-11): عدسة وحيدة المعطيات: قانون $set(s, get(s)) = s$. المطلوب: ماذا يمنع؟ الحل: الخطوة 1: يمنع فقدان المعلومة غير المقروءة. النتيجة: حفظ كامل. الربط بالذكاء الاصطناعي: حالة مُتسقة.

مثال (6.47-12): مثال خاطئ شائع المعطيات: $set((x, y), x') = (x', 0)$ (يصفّر y). المطلوب: هل عدسة؟ الحل: الخطوة 1: لا، $set(s, get(s)) = (x, 0) \neq (x, y)$. النتيجة: ليست عدسة. الربط بالذكاء الاصطناعي: خطأ شائع.

مثال (6.47-13): بصريّات وتركيب متوازٍ المعطيات: بصريّتان على فرعين متوازيين. المطلوب: التركيب. الحل: الخطوة 1: بالجداء المونيّد ($\otimes$) من (4.47). النتيجة: تركيب متوازٍ. الربط بالذكاء الاصطناعي: فروع الشبكة.

مثال (6.47-14): فائدة البرمجة المعطيات: حالة عميقة متداخلة. المطلوب: ماذا توفّر العدسات؟ الحل: الخطوة 1: وصولاً وتحديثاً نظيفين قابلين للتركيب بلا نسخ يدويّ. النتيجة: كود آمن. الربط بالذكاء الاصطناعي: أوزان النماذج.

مثال (6.47-15): خلاصة المعطيات: عدسة أو بصريّة. المطلوب: الجوهر. الحل: الخطوة 1: واجهة قراءة/تحديث قابلة للتركيب تحفظ الاتساق. النتيجة: تجريد قويّ. الربط بالذكاء الاصطناعي: أساس التدرّج.

أخطاء شائعة

- **نسيان قانون** $set(s, get(s)) = s$**:** يسبّب فقدان بيانات.
- **الخلط بين العدسة والدالّة:** العدسة تحمل تحديثاً لا قراءة فقط.
- **تحديث يصفّر باقي الحالة:** يكسر القوانين.
- **ظنّ أنّ التركيب يحتاج** get **وحده:** بل يحتاج تمرير set للداخل.
- **إغفال أنّ البصريّة تعميم:** العدسة حالة الخاصّة الديكارتية.

صياغة رسمية: المخطط (schema) فئة صغيرة $\mathcal{C}$ (كائناتها كيانات/جداول، وسهامها صفات أو مفاتيح أجنبيّة)؛ والمثال (instance) مُقوّب:

$$I : \mathcal{C} \to \mathbf{Set} \tag{9.47}$$

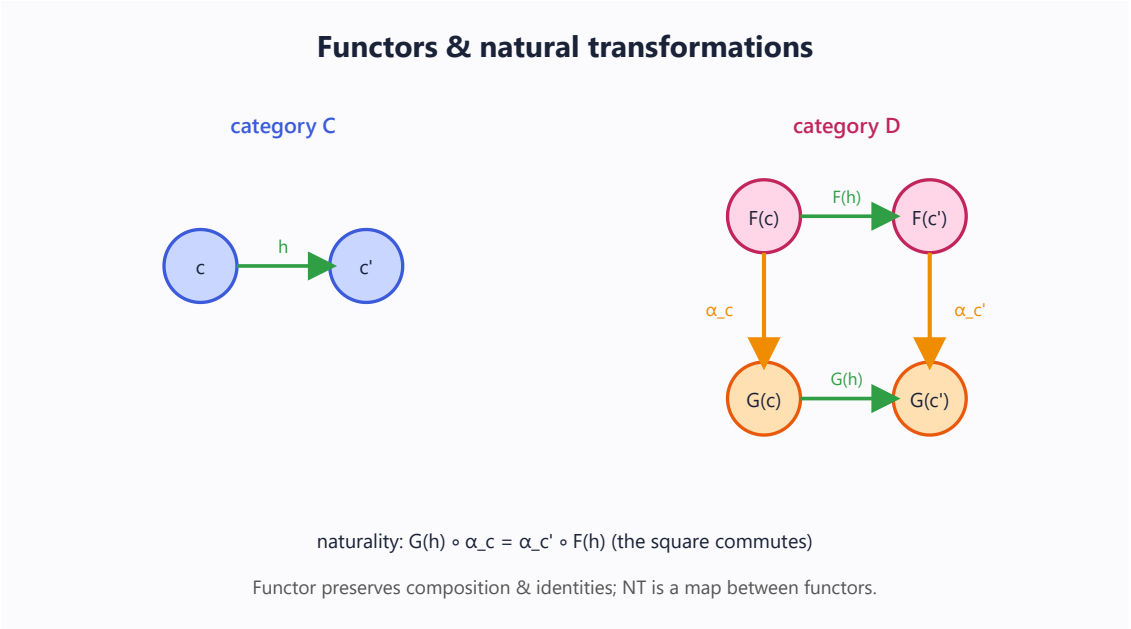
ونقل البيانات على طول مُقوّب $F : \mathcal{C} \to \mathcal{D}$ يتمّ بالسحب العكسيّ $I \circ F$ أو بامتدادات كان (Kan extensions).

جدول الرموز

الرمز	المعنى
$\mathcal{C}$	مخطط قاعدة البيانات
$\mathcal{I}$	مثال (يُعيّن مجموعة لكلّ كيان)
سحب عكسيّ	$\Sigma_F \circ \Delta_F$ (إعادة تسمية/دمج)
امتداد كان	نقل بيانات حقيقيّ (تجميع/إسقاط)

الرسم

<figure> الشكل<figcaption> 6.47: المخطط فئة، والمثال مُقوّب إلى **Set**، والتحويلات الطبيعيّة = ترجمات بين



شكل ٦.٤٧: *
قاعدة بيانات فئويّة

الأمثلة.</figcaption> </figure>

البرهان

الخطوة 1 (المخطط كفئة): الكيانات كائنات، والعلاقات/المفاتيح سهام (قابلة للتركيب). ■

الخطوة 2 (المثال كمُقوّب): لكلّ كيان مجموعة صفوف، ولكلّ سهم دالّة ⇒ مُقوّب إلى **Set**. ■

الخطوة 3 (النقل): السحب العكسيّ يعيد تسمية/دمجًا؛ وامتدادا كان يعطيان التجميع والإسقاط. ■

خمسة عشر مثالاً محلولاً

مثال (1-7.47): مخطط موظّف/قسم المعطيات: كائنان Employee وDepartment، وسهم works_in: Employee→Department. المطلوب: ماذا يعطي المثال؟ الحل: الخطوة 1: مجموعة موظّفين، مجموعة أقسام، ودالّة تربط. النتيجة: مُقوّب إلى **Set**. الربط بالذكاء الاصطناعي: جدول علائقيّ.

مثال (2-7.47): عدد الدوالّ الممكنة المعطيات: 5 موظّفين و2 قسمين. المطلوب: عدد دوالّ النسبة. الحل: الخطوة 1: $2^5 = 32$. النتيجة: 32. الربط بالذكاء الاصطناعي: فضاء الحالات.

مثال (3-7.47): سحب عكسيّ بسيط المعطيات: $F : \mathcal{D} \to \mathcal{C}$ يعيد تسمية؛ I مثال على $\mathcal{C}$. المطلوب: مثال على $\mathcal{D}$. الحل: الخطوة 1: $I \circ F$ (نفس البيانات بمسمّيات $\mathcal{D}$). النتيجة: مثال مُعاد تسميته. الربط بالذكاء الاصطناعي: ترحيل آمن.

مثال (4-7.47): دمج كيانين المعطيات: F يرسل كائنين إلى كائن واحد. المطلوب: الأثر. الحل: الخطوة 1: بالسحب العكسيّ يصيران مجموعة واحدة (اتّحاد). النتيجة: دمج. الربط بالذكاء الاصطناعي: تسطيح المخطط.

مثال (5-7.47): امتداد كان أيسر المعطيات: نقل بيانات مع تجميع. المطلوب: الأداة المناسبة. الحل: الخطوة 1: امتداد كان الأيسر Lan_F (تجميع/إسقاط). النتيجة: تجميع. الربط بالذكاء الاصطناعي: استعلام جماعيّ.

مثال (6-7.47): امتداد كان أيمن المعطيات: نقل مع قيود (أو «جميع»). المطلوب: الأداة المناسبة. الحل: الخطوة 1: امتداد كان الأيمن Ran_F. النتيجة: استعلام تقييديّ. الربط بالذكاء الاصطناعي: شروط معقّدة.

مثال (7-7.47): اتّساق القيود المعطيات: سهم obligatoire من Employee. المطلوب: ماذا يفرض؟ الحل: الخطوة 1: كلّ موظّف له قسم (الدالّة كلّيّة). النتيجة: تكامل مرجعيّ. الربط بالذكاء الاصطناعي: قيد قاعدة البيانات.

مثال (8-7.47): تحويل طبيعيّ كمقارنة المعطيات: مثالان I, J على نفس المخطط. المطلوب: كيف نقارنهما؟ الحل: الخطوة 1: تحويل طبيعيّ $\alpha : I \Rightarrow J$ (دوالّ متّسقة مع المخطط). النتيجة: ترجمة متّسقة. الربط بالذكاء الاصطناعي: مطابقة المخططات.

مثال (9-7.47): مسار في المخطط المعطيات: Employee→Department→Location. المطلوب: المعنى. الحل: الخطوة 1: تركيب سهام = استعلام متعدّد القفزات. النتيجة: وصول غير مباشر. الربط بالذكاء الاصطناعي: استعلام متسلسل.

مثال (10-7.47): هويّة في المخطط المعطيات: سهم id على Employee. المطلوب: المعنى. الحل: الخطوة 1: «نفس الموظّف» (علاقة بلا تغيير). النتيجة: مرجع ذاتيّ. الربط بالذكاء الاصطناعي: مفتاح أساسيّ.

مثال (11-7.47): حجم قاعدة البيانات المعطيات: 3 كيانات بأحجام 100، 50، 10 صفوف. المطلوب: الإجمالي. الحل: الخطوة 1: $100 + 50 + 10 = 160$. النتيجة: 160 صفًّا. الربط بالذكاء الاصطناعي: حجم التخزين.

مثال (12-7.47): إسقاط عمود المعطيات: نُسقط صفةً من الكيان. المطلوب: الأثر على المثال. الحل: الخطوة 1: تصبح الدالّة مُهمَلة ⇒ بيانات أقلّ. النتيجة: إسقاط. الربط بالذكاء الاصطناعي: اختيار الميزات.

مثال (13-7.47): اتّحاد مخططين المعطيات: مخططان بكيان مشترك. المطلوب: الدمج. الحل: الخطوة 1: نأخذ pushout (جمع على المشترك) ⇒ مخطط موحّد. النتيجة: مخطط موحّد. الربط بالذكاء الاصطناعي: تكامل الأنظمة.

مثال (14-7.47): استعلام كـlimit المعطيات: نريد صفوفاً تحقّق قيدين. المطلوب: التفسير الفئويّ. الحل: الخطوة 1: الاستعلام = limit (تقاطع القيود) داخل الفئة. النتيجة: حدّ. (limit) الربط بالذكاء الاصطناعي: SQL فئويّ.

مثال (15-7.47): خلاصة المعطيات: مخطط ومثال. المطلوب: المكسب. الحل: الخطوة 1: قواعد البيانات تُصاغ فئويّاً ⇒ نقلٌ آمن ومُثبت. النتيجة: هندسة بيانات قويّة. الربط بالذكاء الاصطناعي: إدارة البيانات.

أخطاء شائعة

- **الخلط بين السحب العكسيّ وامتداد كان:** الأوّل إعادة تسمية، والثاني نقل فعليّ.
- **نسيان أنّ المخطط فئة:** القيود تُصاغ كسهام لا كشروط خارجيّة.
- **ظنّ أنّ المثال جدول واحد:** بل مُقوّب (عدّة مجموعات مترابطة).
- **إغفال التحويلات الطبيعيّة كمقارنات:** هي أداة مطابقة المخططات.

- **الخلط بين الاستعلام والـlimit:** كثير من الاستعلامات limits فئويّة.

صياغة رسمية: كلّ طبقة شبكة تُرى كبصريّة (تمريرة أماميّة وخلفيّة)؛ والشبكة كلّها تركيبها المونيّد:

$$\text{layer} : (P,\ A) \to B, \qquad \text{backward} : P \times B' \to A' \tag{10.47}$$

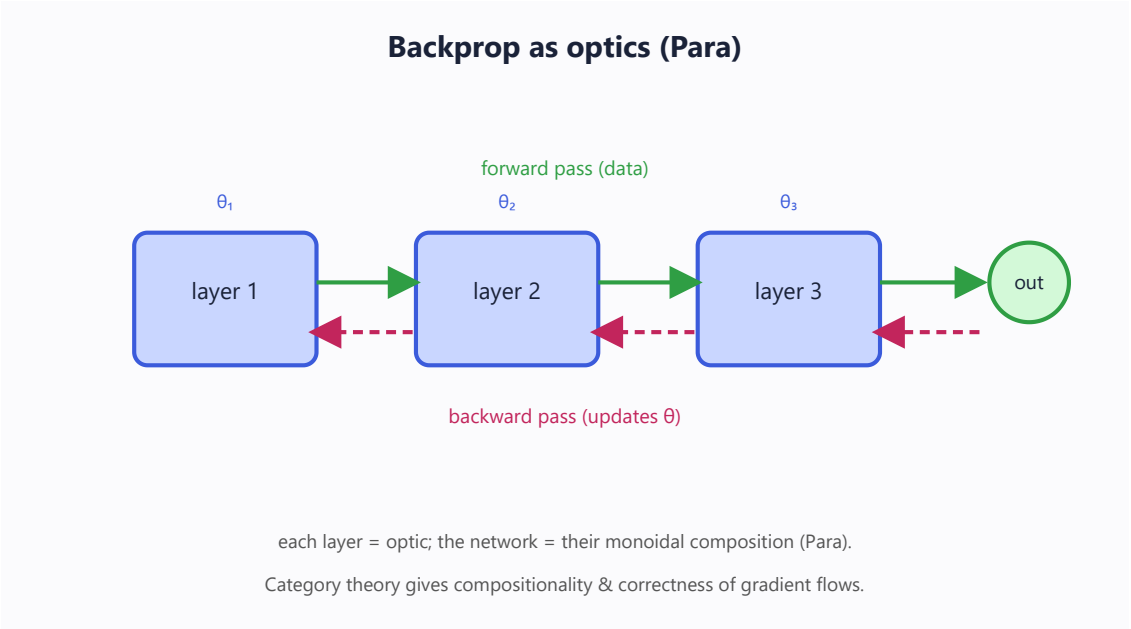
وفي فئة Para يُصبح تعلّم المعاملات جزءاً من السهم نفسه، فيبقى التركيب تركيباً لِبصريّات.

جدول الرموز

الرمز	المعنى
P	كائن المعاملات (الأوزان)
$A \to B$	التمريرة الأماميّة
A'	المتبقّي الخلفي (التدرّج)
Para	فئة السهام ذات المعاملات

الرسم

<figure> الشكل<figcaption> 7.47: الطبقات بصريّات؛ الأماميّ ينشر البيانات والخلفيّ يُحدّث الأوزان، والتركيب



شكل ٧.٤٧: *
النشر العكسي كبصريّات

يحفظ الاثنين.</figcaption> </figure>

البرهان

الخطوة 1 (الطبقة كبصريّة): الأماميّة تحسب الخرج، والخلفيّة توزّع التدرّج على المدخل والمعاملات. ■

الخطوة 2 (التركيب): تركيب بصريّتين = تركيب الأماميّتين وتركيب الخلفيّتين بالترتيب المعكوس. ■

الخطوة 3 (صحّة النشر العكسيّ): قوانين البصريّات تضمن أنّ التركيب يُنتج تدرّجاً صحيحاً للكلّ (لا يحتاج مشتقّة يدويّة). ■

خمسة عشر مثالاً محلولاً

مثال (47.8-1): طبقة خطّيّة المعطيات: $y = Wx + b$، $x \in \mathbb{R}^3$، $W \in \mathbb{R}^{2\times 3}$. المطلوب: شكل الخرج. الحل: الخطوة 1: $y \in \mathbb{R}^2$. النتيجة: $\mathbb{R}^2$. الربط بالذكاء الاصطناعي: تحويل أفينيّ.

مثال (47.8-2): التمريرة الخلفيّة المعطيات: تدرّج الخرج $\partial L/\partial y \in \mathbb{R}^2$. المطلوب: تدرّج W. الحل: الخطوة 1: $\partial L/\partial W = (\partial L/\partial y)\, x^\top$ (شكل 2×3). النتيجة: مصفوفة 2×3. الربط بالذكاء الاصطناعي: تحديث الأوزان.

مثال (47.8-3): تدرّج المدخل المعطيات: من (47.8-2). المطلوب: $\partial L/\partial x$. الحل: الخطوة 1: $W^\top(\partial L/\partial y)$ (شكل 3). النتيجة: متّجه في $\mathbb{R}^3$. الربط بالذكاء الاصطناعي: نشر للخلف.

مثال (47.8-4): تركيب طبقتين المعطيات: طبقتان f, g بأماميّتين وخلفيّتين. المطلوب: الأماميّة المركّبة. الحل: الخطوة 1: $g \circ f$ (التركيب المعتاد). النتيجة: أماميّة مركّبة. الربط بالذكاء الاصطناعي: شبكة عميقة.

مثال (47.8-5): الترتيب الخلفيّ المعطيات: من (47.8-4). المطلوب: ترتيب الخلفيّتين. الحل: الخطوة 1: معكوس الأماميّة (خلفيّة g ثمّ خلفيّة f). النتيجة: معكوس. الربط بالذكاء الاصطناعي: قاعدة السلسلة.

مثال (47.8-6): معاملات في Para المعطيات: سهم $(P, A) \to B$. المطلوب: ماذا يمثّل P؟ الحل: الخطوة 1: فضاء المعاملات (الأوزان/الانحيازات) المُتعلَّمة. النتيجة: معاملات السهم. الربط بالذكاء الاصطناعي: أوزان التدريب.

مثال (47.8-7): تركيب في Para المعطيات: سهمان بمعاملات P_1, P_2. المطلوب: معاملات المركّب. الحل: الخطوة 1: $P_1 \times P_2$ (أو $P_1 \otimes P_2$) $\Rightarrow$ معاملات مجتمعة. النتيجة: $P_1 \otimes P_2$. الربط بالذكاء الاصطناعي: أوزان الشبكة كلّها.

مثال (47.8-8): دالّة التنشيط المعطيات: ReLU أماميّة $y = \max(0, x)$. المطلوب: خلفيّتها. الحل: الخطوة 1: تمرير التدرّج إن كان $x > 0$ وإلاّ صفر. النتيجة: بوّابة التدرّج. الربط بالذكاء الاصطناعي: اشتقاق ReLU.

مثال (47.8-9): خسارة كبصريّة نهائيّة المعطيات: $L : \mathbb{R}^C \to \mathbb{R}$. المطلوب: خلفيّتها. الحل: الخطوة 1: تدرّج الخسارة = بداية النشر العكسيّ. النتيجة: بدء الخلفيّة. الربط بالذكاء الاصطناعي: هدف التدريب.

مثال (47.8-10): عدد المعاملات المعطيات: طبقة 3×2 + انحياز 2. المطلوب: العدد. الحل: الخطوة 1: $6 + 2 = 8$. النتيجة: 8. الربط بالذكاء الاصطناعي: حجم النموذج.

مثال (47.8-11): بصريّة متوازية المعطيات: فرعان متوازيان على نفس المدخل. المطلوب: التركيب. الحل: الخطوة 1: بالجداء المونيّد $\otimes$ (من 47.4). النتيجة: تركيب متوازٍ. الربط بالذكاء الاصطناعي: فروع الشبكة.

مثال (47.8-12): صحة التدرّج المعطيات: شبكة مركّبة من بصريّات صالحة. المطلوب: هل التدرّج صحيح؟ الحل: الخطوة 1: نعم؛ قوانين البصريّات تضمن قاعدة السلسلة. النتيجة: مضمون. الربط بالذكاء الاصطناعي: autodiff صحيح.

مثال (47.8-13): ميزة التركيبية المعطيات: نستبدل طبقةً بأخرى. المطلوب: ماذا يلزم؟ الحل: الخطوة 1: فقط تطابق الأنواع (الواجهة) $\Rightarrow$ قابلية التبديل. النتيجة: تصميم معياريّ. الربط بالذكاء الاصطناعي: هندسة النماذج.

مثال (47.8-14): تدرّج متراكم المعطيات: 3 طبقات، عدد معاملاتها 8 و12 و4. المطلوب: إجمالي المعاملات. الحل: الخطوة 1: $8 + 12 + 4 = 24$. النتيجة: 24. الربط بالذكاء الاصطناعي: حجم التدريب.

مثال (47.8-15): خلاصة المعطيات: شبكة عصبية. المطلوب: الرؤية الفئويّة. الحل: الخطوة 1: تركيب بصريّات؛ الأماميّ يحسب والخلفيّ يعلّم، والتركيب يحفظهما. النتيجة: أساس نظريّ للتعلّم. الربط بالذكاء الاصطناعي: جوهر التعلم العميق.

أخطاء شائعة

- **نسيان أنّ الخلفيّة بالترتيب المعكوس:** قاعدة السلسلة تعكس الترتيب.
- **الخلط بين P والمدخل:** المعاملات كائن مستقلّ في Para.

- **ظنّ أنّ البصريّة تحتاج مشتقّة يدويّة:** التركيب يُنتجها آليّاً.
- **إغفال أنّ التركيب يحفظ التدرّج:** هذا مكسب البصريّات.
- **الخلط بين التركيب المتوازي والمتسلسل:** الأوّل $\otimes$ والثاني $\circ$.

جدول تجميع النظريات

النظرية	العنوان	المعادلة المحوريّة	الرسم
2.47	الفئات والمُقوّبات	$(h \circ g) \circ f = h \circ (g \circ f)$	fig-4701
3.47	التحويلات والمرافقة	$G(h) \circ \alpha_A = \alpha_B \circ F(h)$	fig-4703
4.47	الفئات المونويّدة	$\alpha : (A \otimes B) \otimes C \cong A \otimes (B \otimes C)$	fig-4704
5.47	المونادات	$\mu \circ T\mu = \mu \circ \mu T$	fig-4705
6.47	العدسات والبصريّات	بقوانينها (get, set)	fig-4706
7.47	قواعد البيانات الفئويّة	المخطط فئة، المثال مُقوّب	fig-4702
8.47	التركيبية والنشر العكسي	الطبقة بصريّة، الشبكة تركيبها	fig-4707

عشرون تمريناً محلولاً (إجابات موجزة)

١. **(فئة)** **Set** كائناتها؟ — مجموعات، سهامها دوالّ.

٢. **(هويّة)** $f - \mathrm{id}_B \circ f$.

٣. **(ترابطيّة)** $(h \circ g) \circ f$ مقابل $h \circ (g \circ f)$ — متساويان.

٤. **(مُقوّب)** $F(g) \circ F(f) - F(g \circ f)$.

٥. **(مُقوّب)** $\mathrm{id}_{F(A)} - F(\mathrm{id}_A)$.

٦. **(طبيعيّة)** شرط التحويل — $G(h) \circ \alpha_A = \alpha_B \circ F(h)$.

٧. **(جداء)** عدد الوسطاء لزوج (f, g) — 1.

٨. **(مرافقة)** $F \dashv U$ (حرّ/ناسي) — $\mathrm{Hom}(F(S), M) \cong \mathrm{Hom}(S, U(M))$.

٩. **(مونيّد)** $(\mathbf{Set}, \times)$ لـ $|A \times B|$ لـ 3 و4 — 12.

١٠. **(مونيّد)** $(\mathbf{Vect}, \otimes)$ لـ $\dim(A \otimes B)$ لـ 3 و4 — 12.

١١. **(مونيّد)** $(\mathbf{Set}, +)$ وحدته؟ — $\varnothing$.

١٢. **(موناد قائمة)** $\eta(1) - [1]$.

١٣. **(موناد قائمة)** $\mu([[1], [2, 3]]) - [1, 2, 3]$.

١٤. **(موناد اختياريّ)** $|X + \{None\}|$ لـ X بحجم 3 — 4.

١٥. **(موناد مجموعة)** $|\mathcal{P}(X)|$ لـ X بحجم 3 — 8.

١٦. **(توزيع)** $\mu(0.5\delta_{\delta_0} + 0.5\delta_{\delta_1}) - 0.5\delta_0 + 0.5\delta_1$.

١٧. **(عدسة)** $get(set((3,7),5)) - 5$.

١٨. **(عدسة)** $set((3,7),3) - (3,7)$.

١٩. **(قاعدة بيانات)** 5 موظّفين و2 قسمين، عدد دوالّ النسبة $- 32$.

٢٠. **(شبكة)** طبقة $3 \times 2 + 2$ انحياز $- 8$ معاملات.

فهرس الرموز

الرمز	المعنى	أول ورود
$\mathrm{Ob}(\mathcal{C})$	كائنات الفئة	1.47
$\circ$	تركيب السهام	2.47
$F : \mathcal{C} \to \mathcal{D}$	مُقوّب	2.47
$\alpha : F \Rightarrow G$	تحويل طبيعيّ	3.47
$\otimes, I$	جداء مونيّد ووحدة	4.47
T, η, μ	موناد	5.47
(get, set)	عدسة	6.47

المراجع

- S. Lane, Mac (1998). *Categories for the Working Mathematician*. Springer.
- S. Awodey, (2010). *Category Theory*. Oxford University Press.
- E. Riehl, (2014). *Categorical Homotopy Theory*. Cambridge University Press.
- I. D. Spivak, (2014). *Category Theory for the Sciences*. MIT Press.
- D. Spivak, B., Fong, (2019). *An Invitation to Applied Category Theory: Seven Sketches in Compositionality*. Cambridge.
- R. Tuyéras, D., Spivak, B., Fong, (2019). *Learning Supervised on Backprop as a Functorial Perspective*. LICS.

الهندسة التفاضلية في التعلّم: المتشعّبات والتمثيلات

«فضاء المعاملات ليس مستوياً بالضرورة؛ فهو متشعّبٌ منحنٍ، ومن يفهم انحناءه يفهم لماذا يتباطأ التعلّم.»

حتى الآن درسنا التحسين في فضاءات إقليديّة. لكنّ فضاء الأوزان غالباً هو متشعّبٌ منحنٍ: التدرّج «الأقصر» المعتاد قد يكون طويلاً في الحقيقة. هذا الفصل الختاميّ يبني الهندسة التفاضليّة اللازمة: المتشعّبات، المقاييس الريمانيّة، الانحناء، ثم التدرّج الطبيعي والهبوط الريمانيّ ومتشعّبات التمثيل، وأخيراً الهندسة الإحصائيّة المرتبطة بنظريّة المعلومات (ch27/ch29).

سبع نظريات:

- **2.48 المتشعّبات والفضاء المماسيّ** — خرائط محلّية؛ T_pM أحسن تقريب خطّي عند p.
- **3.48 المقاييس الريمانيّة والجيوديسيّة** — g_p؛ $ds^2 = \sum g_{ij}\,dx^i dx^j$.
- **4.48 ارتباط ليفي-چيڤيتا والنقل المتوازي** — ∇ بلا فتل ويحفظ g.
- **5.48 الانحناء** — $R(X,Y)Z$؛ الانحناء القسميّ K وجذريّ وسُلَّمي.
- **6.48 التدرّج الطبيعي والهبوط الريمانيّ** — $\theta \leftarrow \theta - \eta F^{-1}\nabla L$.
- **7.48 متشعّبات التمثيل وتعلّمها** — تضمينٌ يحفظ الجيوديسيّات.
- **8.48 الهندسة الإحصائيّة والمعلوماتيّة** — مقياس فيشر والاتّصال المزدوج e/m.

كلّ نظرية تتبع القالب: صياغة رسمية ⟵ جدول رموز ⟵ رسم ⟵ برهان ⟵ خمسة عشر مثالاً ⟵ أخطاء شائعة.

الرمز	المعنى	ملاحظة
M	متشعّب ناعم n-الأبعاد	محلّياً $\cong \mathbb{R}^n$
T_pM	الفضاء المماسيّ عند p	أحسن تقريب خطّي
$\{U,\phi\}$	أطلس الخرائط	خرائط متناسقة
g_p	مقياس ريمانيّ عند p	جداء داخليّ على T_pM
ds^2	عنصر الطول التربيعيّ	
R, K	مُلْوِيّ الانحناء والانحناء القسميّ	
F	مصفوفة فيشر	$F = \mathbb{E}[\nabla\ell\nabla\ell^\top]$

الاتفاقيات: نُدخل الجداء الداخليّ بالرمز $g_p(\cdot,\cdot)$؛ التأشير العلويّ/السفليّ يتبع اصطلاح آينشتاين. كلّ المعادلات في كتل LTR.

صياغة رسمية: متشعّب ناعم n-الأبعاد M فضاءٌ ثانٍ معدود، محلّياً $\mathbb{R}^n$ $\cong$، مغطّى بأطلس خرائط $\phi_\alpha : U_\alpha \to \mathbb{R}^n$ متناسقة انتقالياً. عند كلّ $p \in M$ يُعرَّف الفضاء المماسيّ:

$$T_pM = \text{اتجاهات المشتّقات عند } p \cong \mathbb{R}^n \tag{1.48}$$

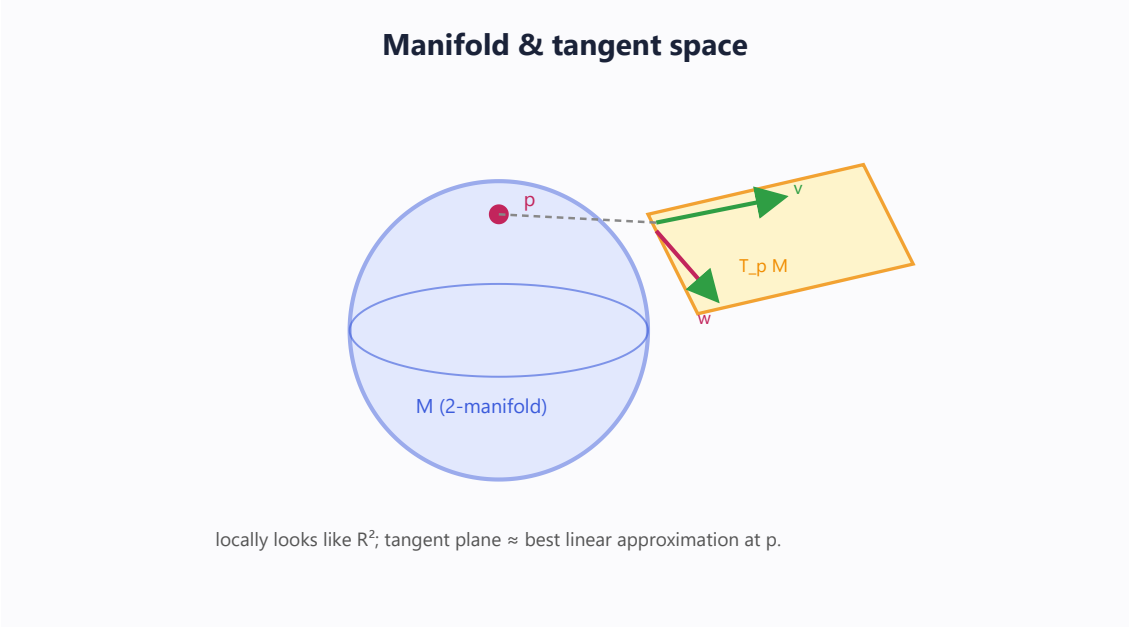
وهو أحسن تقريب خطّي أوّل للمنحنى عند p.

جدول الرموز

الرمز	المعنى
M	المتشعّب
U, ϕ	حيّز مخطط وخرائطه
T_pM	الفضاء المماسيّ
$\gamma(t)$	منحنى ناعم على M

الرسم

<figure> الشكل<figcaption> 1.48: سطح كرويّ M؛ عند النقطة p يمتدّ المستوى المماسيّ T_pM كأحسن تقريب



شكل ١.٤٨: *
المتشعّب والفضاء المماسيّ

خطّي أوّل.</figcaption> </figure>

البرهان

الخطوة 1 (الخرائط المتناسقة): تشارك الخرائط على التداخلات يُنشئ هندسةً قابلة للاشتقاق. ■

الخطوة 2 (التقريب المماسيّ): في المخطط تُحوَّل المنحنيات إلى منحنيات في $\mathbb{R}^n$؛ اتجاهاتها عند p تشكّل T_pM. ■

الخطوة 3 (استقلال المخطط): اختيار المخطط لا يغيّر بُعد T_pM (يبقى n) برغم اختلاف الإحداثيّات. ■

خمسة عشر مثالاً محلولاً

مثال (48.2-1): الفضاء المحيط المعطيات: $M = \mathbb{R}^n$. المطلوب: T_pM. الحل: الخطوة 1: $T_pM = \mathbb{R}^n$ في كلّ نقطة. النتيجة: $\mathbb{R}^n$. الربط بالذكاء الاصطناعي: الفضاء المحيط للأوزان.

مثال (48.2-2): الدائرة المعطيات: $M = S^1$. المطلوب: $\dim M$ وشكل T_pM. الحل: الخطوة 1: $\dim = 1$؛ المماسيّ خطّ عند كلّ نقطة. النتيجة: خطّ. الربط بالذكاء الاصطناعي: متشعّب أحاديّ.

مثال (48.2-3): الكرة المعطيات: $M = S^2$. المطلوب: $\dim T_pM$. الحل: الخطوة 1: $\dim = 2$؛ المماسيّ مستوى. النتيجة: 2. الربط بالذكاء الاصطناعي: سطح ثنائيّ الأبعاد.

مثال (48.2-4): اتجاه خارج الكرة المعطيات: شعاعٌ من المركز نحو p على S^2. المطلوب: هل في T_pM؟ الحل: الخطوة 1: لا، هو النورمال (عموديّ)، لا مماسيّ. النتيجة: خارج. الربط بالذكاء الاصطناعي: فصل المماسيّ عن النورمال.

مثال (48.2-5): أطلس الدائرة المعطيات: تغطية S^1 بخرائط زاويّة. المطلوب: أقلّ عدد مخططات. الحل: الخطوة 1: 2 (كلّ واحدة تخطّي نقطة واحدة). النتيجة: 2. الربط بالذكاء الاصطناعي: تعدد الإسقاطات.

مثال (48.2-6): سطح ضمنيّ المعطيات: $M = \{x \in \mathbb{R}^3 : h(x) = 0\}$ مع $h = x_1^2 + x_2^2 + x_3^2 - 1$. المطلوب: $\dim M$. الحل: الخطوة 1: $\nabla h = (2x_1, 2x_2, 2x_3) \neq 0$ على $M \Rightarrow \dim = 3 - 1 = 2$. النتيجة: 2. الربط بالذكاء الاصطناعي: نظريّة الدالّة الضمنيّة.

مثال (48.2-7): مجال الإحداثيّات المعطيات: مخطط (u, v) عند p. المطلوب: ماذا يصف؟ الحل: الخطوة 1: كلّ نقطة قريبة بمُثْلِي (u, v)؛ ∂_u, ∂_v قاعدة لـT_pM. النتيجة: وصف محلّيّ. الربط بالذكاء الاصطناعي: أساس التمايز.

مثال (48.2-8): تبديل المخطط المعطيات: مخططان (u, v) و(s, t). المطلوب: كيف تتحوّل المتّجهات؟ الحل: الخطوة 1: بجاكوبيّ الانتقال $\partial(s,t)/\partial(u,v)$. النتيجة: تحويل جاكوبيّ. الربط بالذكاء الاصطناعي: تغيير التمثيل.

مثال (48.2-9): منحنى واتجاهه المعطيات: $\gamma(t) = p + t\,q$ على $\mathbb{R}^n$. المطلوب: $\dot\gamma(0)$. الحل: الخطوة 1: q؛ فهو المتّجه المماسيّ. النتيجة: $q \in T_pM$. الربط للذكاء الاصطناعي: اتجاه الحركة.

مثال (48.2-10): بُعد الفضاء المماسيّ المعطيات: M بـ$\dim M = 5$. المطلوب: $\dim T_pM$. الحل: الخطوة 1: 5 (يساوي $\dim M$). النتيجة: 5. الربط للذكاء الاصطناعي: عدد إحداثيّات الخطوة.

مثال (48.2-11): المماسيّ كفضاء متّجهيّ المعطيات: $v, w \in T_pM$؛ $\alpha, \beta \in \mathbb{R}$. المطلوب: $\alpha v + \beta w$؟ الحل: الخطوة 1: يبقى في T_pM (بنية فضاء متّجهيّ). النتيجة: مغلق. الربط للذكاء الاصطناعي: جمع التدرّجات.

مثال (48.2-12): مستويّة محليّة المعطيات: حيّز صغير U عند p. المطلوب: الشكل التقريبيّ. الحل: الخطوة 1: $U \cong \mathbb{R}^n$ (يبدو مستويّاً محليّاً). النتيجة: إقليديّ محلّيّاً. الربط للذكاء الاصطناعي: التطبيع المعتاد.

مثال (48.2-13): حدود المُشعّب المعطيات: M كرة صلبة (ذات حدّ). المطلوب: هل مُشعّب سلس؟ الحل: الخطوة 1: الداخليّ نعم، الحدّ يحتاج معالجة خاصّة. النتيجة: نعم داخليّاً. الربط للذكاء الاصطناعي: قيود المعاملات.

مثال (48.2-14): متشعّب المجموعات الأُسّيّة المعطيات: $T(p) = \{M : M_{ij} > 0, \sum_{ij} M_{ij} = 1\}$. المطلوب: $\dim T(p)$. الحل: الخطوة 1: n^2 مشروط بقيد واحد $\Rightarrow \dim = n^2 - 1$. لـ$n = 2$ لـ3 $\Rightarrow 3$. النتيجة: $n^2 - 1$ (3 لـ$n = 2$). الربط بالذكاء الاصطناعي: مُشعّب المصفوفات المزدوجة.

مثال (48.2-15): خلاصة المعطيات: أيّ متشعّب ناعم. المطلوب: ما يميّزه؟ الحل: الخطوة 1: محلّيّاً إقليديّ وعالميّاً منحنٍ؛ وT_pM تقريبه الخطّي. النتيجة: ناعم وعالميّاً منحنٍ. الربط بالذكاء الاصطناعي: أساس الهندسة.

أخطاء شائعة

- **الخلط بين المماسيّ والنورمال:** النورمال عموديّ، المماسيّ في «الجهة المسطحة».

- **نسيان أنّ بُعد T_pM يطابق بُعد M:** لا يزيد ولا ينقص.
- **الاعتماد على مخطط وحيد:** كثير من المتشعّبات لا تُغطّى بمخطط واحد.
- **إغفال شرط $\nabla h \neq 0$:** بدونه لا ينتج تمايز ضمنيّ.
- **الظنّ أنّ المتشعّب جزء فرعيّ من $\mathbb{R}^n$:** كثير منها كرويّ ولا يُغرس كحلقة.

صياغة رسمية: المقياس الريمانيّ g يعيّن جداءً داخلياً g_p على كلّ T_pM متفاوتاً نعماً، وطول المنحنى ومسافته:

$$\|\gamma\|_g = \int \sqrt{g_p(\dot\gamma,\dot\gamma)}\,dt, \qquad ds^2 = g_{ij}\,dx^i dx^j \tag{2.48}$$

والجيوديسيّ هو المنحنى المُكثِّف محلياً، يحلّ $\nabla_{\dot\gamma}\dot\gamma = 0$ أيّ:

$$\ddot x^k + \Gamma^k_{ij}\dot x^i \dot x^j = 0 \tag{3.48}$$

جدول الرموز

الرمز	المعنى
g_{ij}	مصفوفة المقياس (متماثلة موجبة)
Γ^k_{ij}	رموز كرستوفل
$\exp_p$	الخريطة الأُسّيّة عند p

الرسم

<figure> الشكل<figcaption> 2.48: على الكرة، الجيوديسيّ هو الدائرة العظمى، والمسافة أقصر طول بين نقطتين.</figcaption> </figure>

البرهان

الخطوة 1 (التفاوت الناعم): g مُلْوية ثنائيّة خطّيّة موجبة تتغيّر نعماً مع p. ■

الخطوة 2 (الطول والمسافة): المسافة = أدنى طولٍ بين منحنيّات تربط نقطتين (نظريّة هوف-رينوف). ■

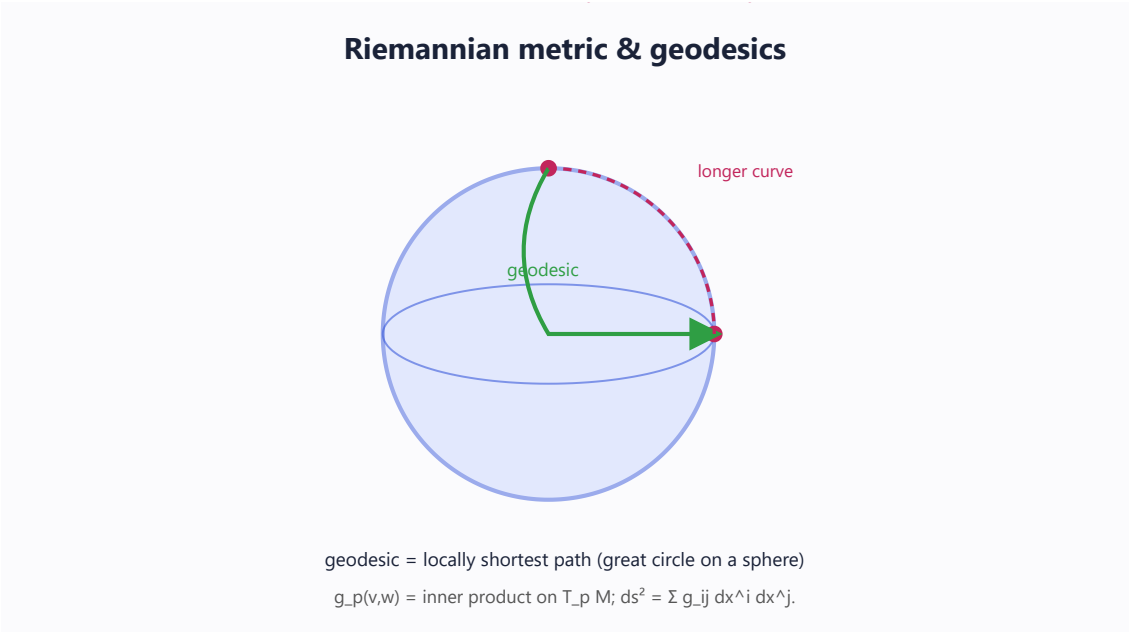
الخطوة 3 (معادلة الجيوديسيّ): المشتقّة الثانية للطول تعطي (3.48)؛ والانطلاق من p بسرعة v يعطي حلّاً وحيداً محلياً (الخريطة الأُسّيّة). ■

خمسة عشر مثالاً محلولاً

مثال (1-3.48): المقياس الإقليديّ المعطيات: $\mathbb{R}^2$ مع $g = I$؛ $v = (3,4)$. المطلوب: $\|v\|_g$. الحل: الخطوة 1: $\|v\|^2 = v^T v = 9 + 16 = 25 \Rightarrow \|v\| = 5$. النتيجة: 5. الربط بالذكاء الاصطناعي: المقياس المعتاد.

مثال (2-3.48): طول القوس الدائريّ المعطيات: S^1 نصف قطر $R = 2$؛ $ds^2 = R^2 d\theta^2$. المطلوب: طول قوس من $\theta = 0$ إلى $\pi/2$. الحل: الخطوة 1: $R \times (\pi/2) = 2 \times 1.571 = 3.142$. النتيجة: $\pi \approx 3.14$. الربط بالذكاء الاصطناعي: قياس المسارات.

مثال (3-3.48): مقياس الكرة المعطيات: S^2 بنصف $R = 1$؛ $ds^2 = d\theta^2 + \sin^2\theta\, d\varphi^2$. المطلوب: عامل $d\varphi$ عند $\theta = \pi/2$ و$\theta = \pi/6$. الحل: الخطوة 1: عند $\pi/2$: العامل $= \sin 1$؛ عند $\pi/6$: العامل $= \sin 0.5$ $\Rightarrow$ 0.25. النتيجة: 1 و0.25. الربط بالذكاء الاصطناعي: تقلّص عرضا عند الأقطاب.



شكل ٢٠٤٨: *
الجيوديسيّات

مثال (4-3.48): طول عامود‌يّ المعطيات: S^2 بنصف $R = 1$؛ خطّ الطول من القطبّ إلى خط الاستواء. المطلوب: الطول. الحل: الخطوة 1: θ من 0 إلى $\pi/2$، $ds^2 = d\theta^2$ (لأنّ φ ثابت) $\Rightarrow \pi/2$. النتيجة: $\pi/2 \approx 1.57$. الربط بالذكاء الاصطناعي: مسافة قطب-خط استواء.

مثال (5-3.48): المقياس القُطريّ المعطيات: $g = \mathrm{diag}(2,3)$، $v = (1,1)$. المطلوب: $\|v\|_g$. الحل: الخطوة 1: $\|v\|^2 = 2\cdot 1 + 3\cdot 1 = 5 \Rightarrow \|v\| = \sqrt{5} \approx 2.236$. النتيجة: 2.236. الربط بالذكاء الاصطناعي: مقياس غير متساوٍ المحاور.

مثال (6-3.48): جيوديسيّ على الكرة المعطيات: نقطتان على S^2. المطلوب: أقصر مسار. الحل: الخطوة 1: الدائرة العظمى المارّة بهما (حتى نقطة وقَطْبها الآخر). النتيجة: دائرة عظمى. الربط بالذكاء الاصطناعي: أقصر طريق.

مثال (7-3.48): تخليق الخريطة الأُسّيّة المعطيات: $\exp_p(v)$ عند p بسرعة v. المطلوب: التعريف. الحل: الخطوة 1: النقطة الواصلة بجيوديسيّ وحدة السرعة بعد زمن $\|v\|$. النتيجة: يربط T_pM بـM. الربط بالذكاء الاصطناعي: خطوة أُسّيّة.

مثال (8-3.48): تحويل المقياس المعطيات: تغيير إحداثيّات $y = y(x)$. المطلوب: كيف يتحوّل g؟ الحل: الخطوة 1: $g' = J^\top g J$ (موتريّ، $J = \partial x/\partial y$). النتيجة: قانون التحويل الموتريّ. الربط بالذكاء الاصطناعي: ثبات المقياس.

مثال (9-3.48): مقياس القرص بوانكاريه المعطيات: $ds^2 = \frac{4(dx^2+dy^2)}{(1-\|x\|^2)^2}$؛ $\|x\| = 0$ مقابل 0.5. المطلوب: عامل التكبير عنديّة. الحل: الخطوة 1: عند 0: $4/1 = 4$؛ عند 0.5: $4/(0.75)^2 = 4/0.5625 = 7.11$. النتيجة: 4 و7.11. الربط بالذكاء الاصطناعي: فراغ يتضخّم عند الحدّ.

مثال (10-3.48): المسافة في قرص بوانكاريه المعطيات: $x = 0$، $y = (0.5,0)$. المطلوب: $d(x,y)$. الحل: الخطوة 1: $d = \operatorname{arcosh}\!\left(1 + \frac{2\|x-y\|^2}{(1-\|x\|^2)(1-\|y\|^2)}\right) = \operatorname{arcosh}(1 + \frac{2(0.25)}{1\times 0.75}) = \operatorname{arcosh}(\frac{5}{3}) = \ln 3 \approx 1.099$. النتيجة: 1.099. الربط بالذكاء الاصطناعي: مسافة قطعيّة.

مثال (11-3.48): مسافة أبعد المعطيات: $y = (0.9,0)$ من $x = 0$. المطلوب: d. الحل: الخطوة 1: $\frac{2(0.81)}{1\times 0.19} = 8.53$؛ $\operatorname{arcosh}(9.53) = \ln(9.53 + \sqrt{89.8}) = \ln(9.53 + 9.48) \approx 2.99$. النتيجة: ≈ 3.0. الربط بالذكاء الاصطناعي: تقارب الحدّ = ما لا نهاية.

مثال (12-3.48): الحجم القياسيّ المعطيات: مربّع الوَحدة في $\mathbb{R}^2$ بـ $g = I$. المطلوب: المساحة. الحل: الخطوة 1: $\sqrt{\det g} \times$ المساحة الإقليديّة $= 1 \times 1 = 1$. النتيجة: 1. الربط بالذكاء الاصطناعي: حجم محدّد بالمقياس.

مثال (13-3.48): التحاكي (isometry) المعطيات: φ يحفظ g. المطلوب: ماذا يحفظ أيضاً؟ الحل: الخطوة 1: يحفظ الأطوال والجيوديسيّات والمسافات. النتيجة: كلّ الهندسة. الربط بالذكاء الاصطناعي: ثبات التمثيل.

مثال (14-3.48): كمال &(١) المعطيات: متشعّب كامل (هوف-رينوف). المطلوب: مضمونها؟ الحل: الخطوة 1: كلّ جيوديسيّ يُمدّد إلى $\mathbb{R}$؛ والطريقان المغلاقان يخلوان منها. النتيجة: أمان نظريّ. الربط بالذكاء الاصطناعي: تحسين مضمون.

مثال (15-3.48): خلاصة المعطيات: مقياس ريمانيّ g. المطلوب: دوره في التحسين؟ الحل: الخطوة 1: يحدّد معنى «القرب» و«السرعة» $\Rightarrow$ يحدّد الخطوة المثلى. النتيجة: أساس الهبوط الريمانيّ. الربط بالذكاء الاصطناعي: يربط بـ(6.48).

أخطاء شائعة

- **نسيان أنّ g يتغيّر مع p:** ليست ثابتة كما في $\mathbb{R}^n$.
- **استخدام مسافة إقليديّة على متشعّب منحنٍ:** قد تُقصّر المسار غير الجيوديسيّ.
- **إغفال شرط التعريف الموجبّ لـg:** مصفوفة المقياس موجبة لكلّ p.
- **الخلط بين $\|v\|_g$ والقيمة المطلقة الإقليديّة.**
- **نسيان قانون تحويل المقياس $J^{\top} g J$.**

صياغة رسمية: الارتباط ∇ يربط الاتجاه بالاشتقاق، وارتباط ليفي-چيڤيتا هو الوحيد بلا فتل ومتوافق مع المقياس:

$$\nabla_X Y - \nabla_Y X = [X, Y], \qquad X\, g(Y, Z) = g(\nabla_X Y, Z) + g(Y, \nabla_X Z) \tag{4.48}$$

ورموزه Γ_{ij}^{k}؛ ويُدعى المتّجه V موازيّاً على γ إذا $\nabla_{\dot\gamma} V = 0$.

جدول الرموز

الرمز	المعنى
$\nabla_X Y$	المشتقّة الاتجاهيّة
Γ_{ij}^{k}	رموز كرستوفل
$[X, Y]$	قوس لي
النقل المتوازي	إزاحة V بلا تدوير محلّيّ

الرسم

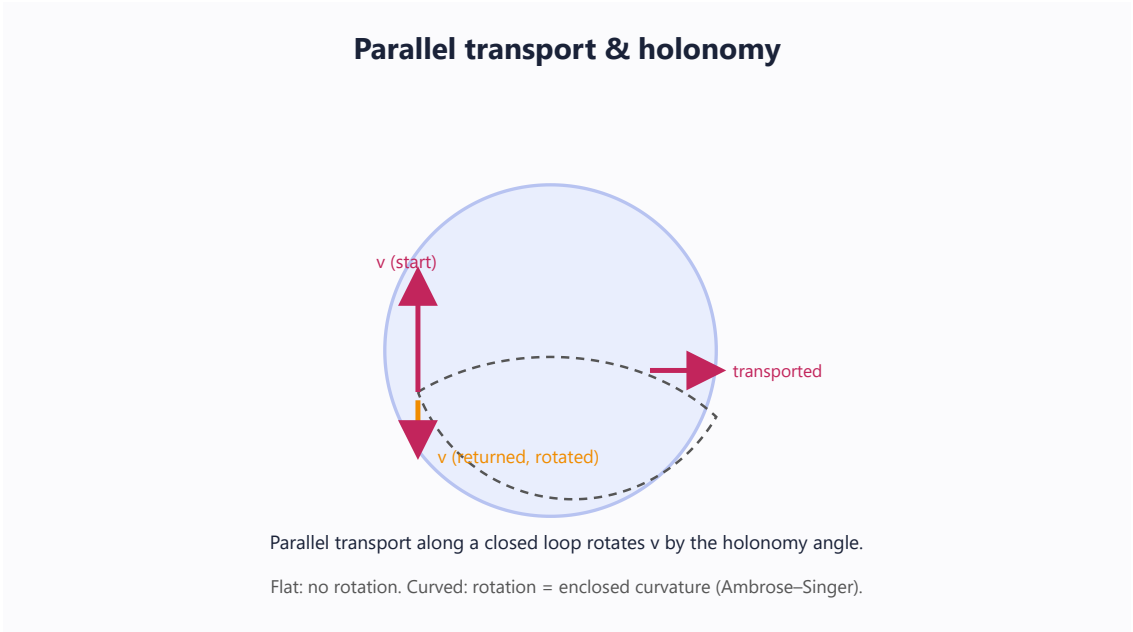
<figure> الشكل<figcaption> 3.48: نقلُ متّجه بموازاةٍ حول حلقة على السطح يُعيده مُدوّراً بزاوية الهولونوميّ.</figcaption> </figure>

البرهان

الخطوة 1 (الوجود والوحدة): (4.48) معادلتان خطّيّتان في Γ $\Rightarrow$ حلّ وحيد (ليفي-چيڤيتا) على كلّ مُشعّب ريمانيّ. ■

الخطوة 2 (التوافق): طولَي أيّ متّجهين موازيين يبقيان ثابتيّن أثناء النقل. ■

الخطوة 3 (الهولونوميّ): في فضاء منحنٍ، النقل حول حلقة يُدوّر المتّجه بمقدار الانحناء المحصور (Ambrose–Singer). ■



شكل ٣٠٤٨: *
النقل المتوازي

خمسة عشر مثالاً محلولاً

مثال (1-4.48): في الإحداثيّات الديكارتيّة المعطيات: $\mathbb{R}^n$ مع $g = \delta$. المطلوب: Γ^k_{ij}. الحل: الخطوة 1: كلّ $\Gamma = 0$ (الإحداثيّات مستقيمة). النتيجة: $\Gamma = 0$. الربط بالذكاء الاصطناعي: مشتقّة عاديّة.

مثال (2-4.48): الإحداثيّات القُطبيّة المعطيات: $ds^2 = dr^2 + r^2 d\theta^2$. المطلوب: رموز كرستوفل غير الصفريّة. الحل: الخطوة 1: $\Gamma^r_{\theta\theta} = -r$ و$\Gamma^\theta_{r\theta} = \Gamma^\theta_{\theta r} = 1/r$. النتيجة: $(-r,\ 1/r)$. الربط بالذكاء الاصطناعي: مشتقّة تتذكّر المنحنيات.

مثال (3-4.48): قيمة عدديّة في القطبيّة المعطيات: $r = 2$. المطلوب: $\Gamma^r_{\theta\theta}$ و$\Gamma^\theta_{r\theta}$. الحل: الخطوة 1: $\Gamma^r_{\theta\theta} = -2$؛ $\Gamma^\theta_{r\theta} = 1/2 = 0.5$. النتيجة: $-2,\ 0.5$. الربط بالذكاء الاصطناعي: حساب صريح.

مثال (4-4.48): الجيوديسيّ القطريّ المعطيات: معادلة الجيوديسيّ في القطبيّة. المطلوب: أيّ المسارات جيوديسيّة؟ الحل: الخطوة 1: الخطوط المستقيمة عبر المركز ($\theta =$ ثابت) والدوائر المركزية بشرط. النتيجة: خطوط قُطريّة. الربط بالذكاء الاصطناعي: مسار مستقيم.

مثال (5-4.48): بلا فتل المعطيات: $\nabla_X Y - \nabla_Y X$. المطلوب: الشرط. الحل: الخطوة 1: $[X, Y]$ يساوي الفعل التبادليّ (لا فتل). النتيجة: متطابق. الربط بالذكاء الاصطناعي: تناظر الاتجاه.

مثال (6-4.48): حفظ الطول المعطيات: V, W موازيّان على γ. المطلوب: $g(V, W)$؟ الحل: الخطوة 1: ثابت على طول γ (التوافق مع g). النتيجة: ثابت. الربط بالذكاء الاصطناعي: لا فقدان مقياس.

مثال (7-4.48): النقل حول خط عرض المعطيات: حلقة على خطّ عرض في الكرة. المطلوب: هل يدور المتّجه؟ الحل: الخطوة 1: نعم؛ يدور بمقدار $\sin\phi \times$المنطقة (ليس حتّى خط الاستواء). النتيجة: يدور. الربط بالذكاء الاصطناعي: هولونوميّ حقيقيّ.

مثال (8-4.48): على خط الاستواء المعطيات: $\phi = 0$ (خطّ الاستواء). المطلوب: الهولونوميّ. الحل: الخطوة 1: خط الاستواء جيوديسيّ $\Rightarrow$ لا تدوير إجماليّ داخليّاً (0). النتيجة: 0. الربط للذكاء الاصطناعي: جيوديسيّ $\Rightarrow$ موازٍ ذاتيّاً.

مثال (48.4-9): رموز كرستوفل الكرويّة المعطيات: S^2 بـ(θ,φ). المطلوب: $\Gamma^{\varphi}_{\theta\varphi}$. الحل: الخطوة 1: $\Gamma^{\varphi}_{\theta\varphi}=\Gamma^{\varphi}_{\varphi\theta}=\cot\theta$. النتيجة: $\cot\theta$. الربط للذكاء الاصطناعي: حساب كرويّ.

مثال (48.4-10): عند خط الاستواء المعطيات: $\theta=\pi/2$. المطلوب: $\cot(\pi/2)$ و$\Gamma^{\theta}_{\varphi\varphi}$. الحل: الخطوة 1: $\cot(\pi/2)=0$؛ $\Gamma^{\theta}_{\varphi\varphi}=-\sin\theta\cos\theta=0$. النتيجة: $0,0$. الربط للذكاء الاصطناعي: تبسيط عند الاستواء.

مثال (48.4-11): الحلقة الصغيرة المعطيات: حلقة صغيرة جدّاً. المطلوب: الهولونوميّ. الحل: الخطوة 1: يقارب الصفر (محليّاً إقليديّ). النتيجة: $0\approx$. الربط للذكاء الاصطناعي: الانحناء محلّيّ صغير.

مثال (48.4-12): الفضاء المسطّح المعطيات: $K=0$ في كلّ مكان. المطلوب: سلوك النقل. الحل: الخطوة 1: لا هولونوميّ؛ النقل مستقلّ عن المسار. النتيجة: مستقلّ. الربط للذكاء الاصطناعي: حالة إقليديّة.

مثال (48.4-13): التدرّج الريمانيّ المعطيات: $g_p(\operatorname{grad}F,v)=dF[v]$ لكلّ v. المطلوب: كيف يعرّف grad؟ الحل: الخطوة 1: بالتطابق عبر g؛ خلاف التدرّج الإقليديّ. النتيجة: تدرّج ريمانيّ. الربط للذكاء الاصطناعي: يربط بـ(48.6).

مثال (48.4-14): أهمية عمليّة المعطيات: فضاء أوزان منحنٍ. المطلوب: فائدة ليفي-چيڤيتا؟ الحل: الخطوة 1: يعطي مشتقّات ونقلا صحيحاً على المنحنيات (تدرّج طبيعيّ). النتيجة: تفاضل صحيح. الربط للذكاء الاصطناعي: أساس التفاضل على المتشعّبات.

مثال (48.4-15): خلاصة المطلوب: ما يميّزه؟ الحل: الخطوة 1: هو الارتباط الوحيد المتوافق مع g وبلا فتل $\Rightarrow$ الطريقة القياسيّة للاشتقاق. النتيجة: الارتباط القياسيّ. الربط للذكاء الاصطناعي: مرجع نظريّ.

أخطاء شائعة

- **نسيان أنّ Γ ليست موتريّة:** فهي رموز ارتباط لا كميّة هندسيّة.
- **الخلط بين المشتقّة الاتجاهيّة والعاديّة:** الاتجاهيّة تعتمد على المسار.
- **نسيان شرط التوافق مع g:** بلا حفظ g لا طول محفوظ.
- **الظنّ أن النقل المتوازي مستقلّ دائماً عن المسار:** الهولونوميّ يعتمد على الانحناء.
- **التعميم الخاطئ من الديكارتيّة:** في الإحداثيّات المنحنية $\Gamma\neq 0$ حتّى في فضاء مسطّح.

صياغة رسمية: مُلْوِيّ الانحناء يقيس فشل تبادل المشتقّات الاتجاهيّة:

$$R(X,Y)Z=\nabla_X\nabla_Y Z-\nabla_Y\nabla_X Z-\nabla_{[X,Y]}Z \tag{5.48}$$

والانحناء القسميّ (للمستوي المولّد بـX,Y):

$$K(X,Y)=\frac{g(R(X,Y)Y,X)}{\|X\|^2\|Y\|^2-g(X,Y)^2} \tag{6.48}$$

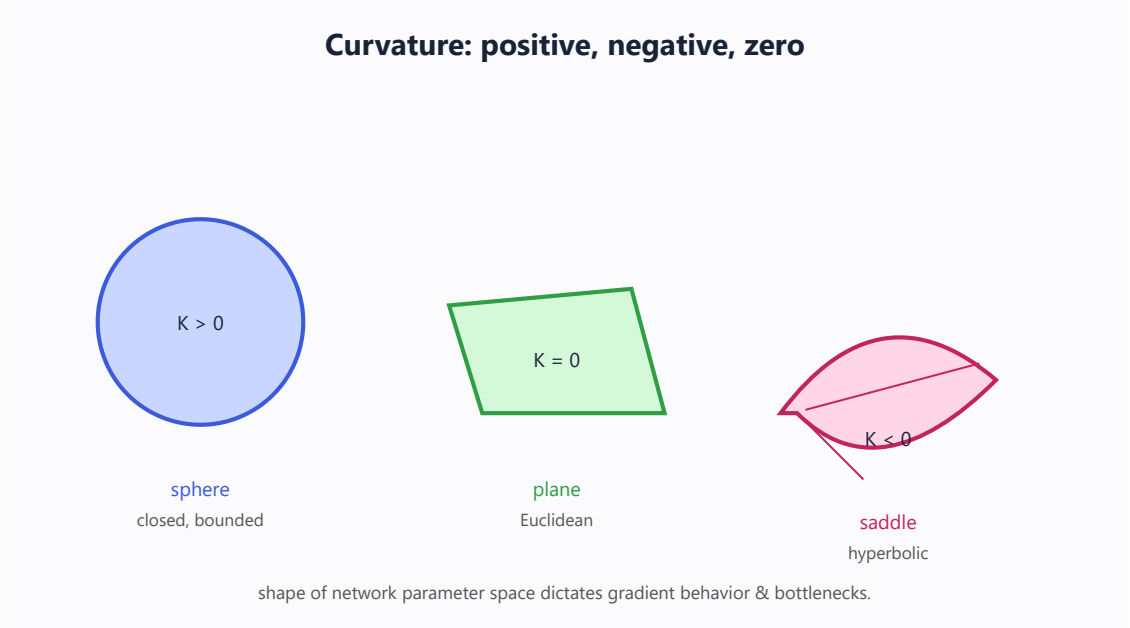
والانحناء الجذريّ $\operatorname{Ric}(X,Y)=\operatorname{tr}\big(Z\mapsto R(Z,X)Y\big)$، والسلّمي $S=\operatorname{tr}_g\operatorname{Ric}$.

جدول الرموز

الرمز	المعنى
R	مُلْوِيّ الانحناء
K	الانحناء القسميّ
Ric, S	الجذريّ والسلّميّ
$K>0, K=0, K<0$	كروي، مسطّح، سرجيّ

الرسم

<figure> الشكل<figcaption> 4.48: الانحناء الموجب (كرة) والمنعدم (مستوي) والسال- (سرج)؛ يصنّف الهندسة



شكل ٤٠٤٨: *
أنواع الانحناء

المحليّة.</figcaption> </figure>

البرهان

الخطوة 1 (تعريف R): R يختبر أيّ المشتقّتين الاتجاهيّتين لا تتبادلان. ■

الخطوة 2 (القسميّ): يلخّص R في رقم واحد لكلّ مستويّ مماسيّ. ■

الخطوة 3 (الاتّساق): R موتوريّ في وسائطه؛ سلوك الجيوديسيّات المجاورة يحدّده (معادلات جاكوبيّ). ■

خمسة عشر مثالاً محلولاً

مثال (1-5.48): المستوى المعطيات: $\mathbb{R}^2$. المطلوب: K. الحل: الخطوة 1: كلّ $K=0 \Rightarrow R=0 \Rightarrow \Gamma=0$. النتيجة: 0. الربط بالذكاء الاصطناعي: الهندسة الإقليديّة.

مثال (2-5.48): الكرة نصفها 1 المعطيات: S^2 بنصف $R=1$. المطلوب: K. الحل: الخطوة 1: $K=1/R^2=1$. النتيجة: 1. الربط بالذكاء الاصطناعي: انحناء موجب ثابت.

مثال (3-5.48): كرة أكبر المعطيات: $R=2$. المطلوب: K. الحل: الخطوة 1: $K=1/4=0.25$. النتيجة: 0.25. الربط بالذكاء الاصطناعي: الكرات الأكبر أنعم.

مثال (48.5-4): الكرة الأصغر المعطيات: $R = 0.5$. المطلوب: K. الحل: الخطوة 1: $1/0.25 = 4$. النتيجة: 4. الربط بالذكاء الاصطناعي: انحناء حادّ.

مثال (48.5-5): الكرة القطعيّة المعطيات: نصف كرة قاطعها $-1 =$. المطلوب: K. الحل: الخطوة 1: $K = -1$ (ثابت). النتيجة: -1. الربط بالذكاء الاصطناعي: انحناء سالب ثابت.

مثال (48.5-6): الطارة المعطيات: سطح طارة في $\mathbb{R}^3$. المطلوب: توزيع K. الحل: الخطوة 1: خارجياً موجبة، داخلياً سالبة، المتوسّط صفريه. النتيجة: متغيّر الإشارة. الربط للذكاء الاصطناعي: خصائص مختلطة.

مثال (48.5-7): الانحناء السلّمي للكرة المعطيات: S^2 بنصف $R = 1$. المطلوب: $S = 2/R^2$. الحل: الخطوة 1: $S = 2$. النتيجة: 2. الربط للذكاء الاصطناعي: مقياس السلّم الهندسيّ.

مثال (48.5-8): الانحناء الجذريّ للكرة المعطيات: S^n بانحناء قسميّ K ثابت. المطلوب: Ric بالنسبة للمقياس. الحل: الخطوة 1: $\mathrm{Ric} = (n-1)K\,g$؛ لـ $\mathrm{Ric} = g \Rightarrow S^2, K = 1$. النتيجة: $\mathrm{Ric} = g$. الربط للذكاء الاصطناعي: متشعّب آينشتاينيّ.

مثال (48.5-9): العدد السالب والتوسّع المعطيات: $K < 0$ في منطقة. المطلوب: سلوك الجيوديسيّات. الحل: الخطوة 1: تتباعد جيوديسيّات متجاورة بسرعة أكبر من الإقليديّة. النتيجة: تباعد سريع. الربط للذكاء الاصطناعي: فضاء واسع.

مثال (48.5-10): العدد الموجب والتجمّع المعطيات: $K > 0$. المطلوب: سلوك الجيوديسيّات. الحل: الخطوة 1: تتباعد ثمّ تلتقي (مثل خطوط الطول عند القطبين). النتيجة: جذب متقاطع. الربط للذكاء الاصطناعي: فضاء مغلق.

مثال (48.5-11): الانحناء والهبوط المعطيات: فضاء معاملات منحنٍ. المطلوب: أثر $K > 0$؟ الحل: الخطوة 1: هبوط أبطأ بسبب تقوّس المسارات، نقاط سرج أكثر. النتيجة: تبطؤ التحسين. الربط بالذكاء الاصطناعي: أداء التعلّم.

مثال (48.5-12): الانحناء والهبوط في $K < 0$ المطلوب: سلوك الهبوط. الحل: الخطوة 1: سلوك أقرب للإقليديّ؛ انحراف أقلّ للجيوديسيّات. النتيجة: سلوك أفضل. الربط للذكاء الاصطناعي: فضاءات هيبربوليّة فعّالة للأشجار.

مثال (48.5-13): معادلة جاكوبيّ المعطيات: Y مجال جاكوبيّ على سطح جيوديسيّ. المطلوب: المعادلة. الحل: الخطوة 1: $\frac{D^2}{dt^2}Y + R(Y,\dot\gamma)\dot\gamma = 0$؛ الانحناء هو الحدّ المُشتقّ. النتيجة: انحناء يقود التباعد. الربط للذكاء الاصطناعي: حساب التشوّه.

مثال (48.5-14): الانحناء القسميّ حسابيّاً المعطيات: $R(\partial_i,\partial_j)\partial_j = R^k{}_{lij}\partial_k$. المطلوب: صيغة K. الحل: الخطوة 1: $K = R^l{}_{ilj}$ في قاعدة معيّاريّة. النتيجة: صيغة موجزة. الربط للذكاء الاصطناعي: حساب عدديّ.

مثال (48.5-15): خلاصة المطلوب: لماذا نهتمّ بالانحناء؟ الحل: الخطوة 1: يحدّد شكل فضاء المعاملات فيوجّه اختيار الخطوات والتهيئات. النتيجة: شكل الفضاء. الربط للذكاء الاصطناعي: هندسة التعلّم.

أخطاء شائعة

- **الظنّ أنّ الانحناء ثابت على المتشعّب:** قد يتغيّر من منطقة لأخرى (الطارة).
- **الخلط بين R وK:** الأوّل موتور، والثاني رقم لكلّ مستويّ.
- **نسيان $\|X\|^2\|Y\|^2 - g(X,Y)^2$ في مقام K.**
- **الخلط بين Ric وR:** الجذريّ أثرٌ للموتريّ.
- **إغفال أنّ K يعتمد على المستويّ المختار:** انحناء «الفضاء» الأوّل.

صياغة رسمية: على الفضاء الإحصائيّ المُجهّز بمقياس فيشر، التدرّج الطبيعي هو «الأسرع صعوداً» بمعيار المسافة على التوزيعات:

$$\tilde{\nabla} L(\theta) = F(\theta)^{-1} \nabla L(\theta), \qquad \theta_{t+1} = R_x\big(\theta_t - \eta\, \tilde{\nabla} L(\theta_t)\big) \tag{7.48}$$

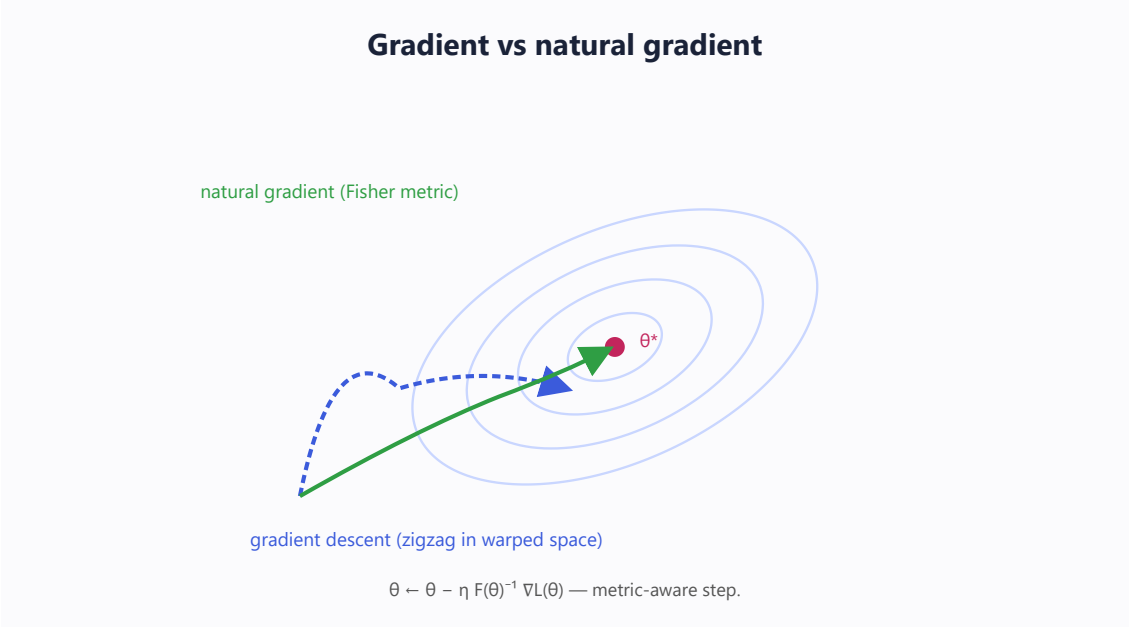
حيث $F = \mathbb{E}[\nabla \ell \nabla \ell^\top]$ وR_x عملية الإرجاع (retraction).

جدول الرموز

الرمز	المعنى
$\tilde{\nabla}$	التدرّج الطبيعي
$F(\theta)$	مصفوفة فيشر (مقياس التوزيع)
R_x	إرجاع من المماسيّ إلى المُشعّب
K-FAC	تقريب طبقيّ لـF

الرسم

<figure> الشكل<figcaption>5.48: التدرّج الطبيعي يتبع أقصر مسارٍ على المشعّب الإحصائيّ بدل التعرّج



شكل ٥.٤٨: *
التدرّج الطبيعي

الإقليديّ.</figcaption> </figure>

البرهان

الخطوة 1 (F كمقياس): $D_{KL}(p_{\theta+d\theta}\|p_\theta) = \tfrac{1}{2} d\theta^\top F(\theta) d\theta + O(\|d\theta\|^3)$ (مرتبطة بـch29). ■

الخطوة 2 (اتّجاه الصعود الأسرع): إيجاد $d\theta$ يزيد L أكثر ما يمكن لكلّ وحدة مسافة فيشر $\Rightarrow d\theta = F^{-1}\nabla L$. ■

الخطوة 3 (الإرجاع): $\theta - \eta\tilde{\nabla}$ قد يخرج من المُشعّب؛ R يعيده إليه بدقّة أوّل. ■

خمسة عشر مثالاً محلولاً

مثال (48.6-1): فيشر متناسبة للهويّة المعطيات: $F = 2I$، $\nabla L = (4, 6)$. المطلوب: $\tilde{\nabla} L$. الحل: الخطوة 1: $\tilde{\nabla} = \frac{1}{2}(4, 6) = (2, 3)$. النتيجة: $(2, 3)$. الربط بالذكاء الاصطناعي: نصف خطوة الإقليديّ.

مثال (48.6-2): فيشر قُطريّة المعطيات: $F = \mathrm{diag}(4, 1)$، $\nabla L = (4, 6)$. المطلوب: $\tilde{\nabla}$. الحل: الخطوة 1: $(4/4,\ 6/1) = (1, 6)$. النتيجة: $(1, 6)$. الربط بالذكاء الاصطناعي: إعادة قياس الأبعاد.

مثال (48.6-3): مقارنة بالهبوط العاديّ المعطيات: من (48.6-2)، $\eta = 0.5$. المطلوب: الخطوتان. الحل: الخطوة 1: العاديّة: $(4, 6) - 0.5(4, 6) = (2, 3)$؛الطبيعيّة: $\theta - (0.25, 3)$. النتيجة: المساران مختلفان. الربط للذكاء الاصطناعي: الطبيعي أنسب للتوزيع.

مثال (48.6-4): فيشر لغاوسيّ (معامل متوسط فقط) المعطيات: عائلة $\mathcal{N}(\mu, 1)$ وسيط تعلّم اللوغاريتم $\ell = -\frac{(x-\mu)^2}{2}$. المطلوب: F_μ. الحل: الخطوة 1: $\partial_\mu \ell = (x - \mu)$؛لذا $F_\mu = \mathbb{E}[(x - \mu)^2] = \sigma^2 = 1$. النتيجة: $F_\mu = 1$. الربط بالذكاء الاصطناعي: المقياس يتناسب مع التباين.

مثال (48.6-5): تأثير الخطوة لـμ المعطيات: $F_\mu = 1$، $\nabla L_\mu = 4$، $\eta = 0.5$. المطلوب: $\Delta\mu$. الحل: الخطوة 1: $\Delta\mu = -0.5 \times (4/1) = -2$. النتيجة: -2. الربط بالذكاء الاصطناعي: يقابل الهبوط الإقليديّ هنا.

مثال (48.6-6): فيشر لغاوسيّ كامل (رباعيه) المعطيات: معاملان (μ, σ^2) مع $\sigma = 2$، $\Delta\mu = 0$. المطلوب: $F_{\sigma\sigma}$. الحل: الخطوة 1: $F_{\sigma\sigma} = 2/\sigma^4 = 2/16 = 0.125$. النتيجة: 0.125. الربط بالذكاء الاصطناعي: خطوة أكبر للتباين.

مثال (48.6-7): تحديث التباين المعطيات: $F_{\sigma\sigma} = 0.125$، $\nabla L_\sigma = 1$، $\eta = 0.1$. المطلوب: $\Delta\sigma$. الحل: الخطوة 1: $\Delta\sigma = -0.1 \times (1/0.125) = -0.1 \times 8 = -0.8$. النتيجة: -0.8. الربط للذكاء الاصطناعي: تكبير بمعامل $1/F$.

مثال (48.6-8): الهبوط على الكرة الوحدويّة المعطيات: θ يجب أن يبقى على S^{n-1}. المطلوب: عملية إرجاع مناسبة. الحل: الخطوة 1: $R_\theta(v) = \frac{\theta+v}{\|\theta+v\|}$ بعد إسقاط v على المماسيّ. النتيجة: إرجاع بالطّبقة. الربط بالذكاء الاصطناعي: قيد النموذج الوحدويّ.

مثال (48.6-9): مصفوفات متعامدة (Stiefel) المعطيات: مُشعّب $V_r^n = \{X : X^\top X = I_r\}$. المطلوب: كيف نُحدّث؟ الحل: الخطوة 1: بتفكيك QR أو بإسقاط جذبور (Cayley) على المماسيّ. النتيجة: تحديث QR/كايلي. الربط للذكاء الاصطناعي: أوزان مقيدة.

مثال (48.6-10): مُشعّب المصفوفات المتماثلة الموجبة المعطيات: $\Sigma \succ 0$؛الهدف(SPD) تبقى موجبة. المطلوب: الإرجاع. الحل: الخطوة 1: $R_\Sigma(H) = \Sigma^{1/2} \exp(\Sigma^{-1/2} H \Sigma^{-1/2} t) \Sigma^{1/2}$ (خريطة أُسّيّة). النتيجة: إرجاع SPD. الربط بالذكاء الاصطناعي: منظّم التباين.

مثال (48.6-11): تقريب K-FAC المعطيات: طبقة بـ10^6 معامل. المطلوب: كيف نُقدّر $F^{-1}\nabla L$؟ الحل: الخطوة 1: $F \approx A \otimes S$؛نفصل قُطريّة التنشيط عن قُطريّة المتبقّي. النتيجة: تقريب فعّال. الربط للذكاء الاصطناعي: تعليم عمليّ فعّال.

مثال (48.6-12): العلاقة بطريقة نيوتن المعطيات: θ يُحدَّد بتعظيم اللوغاريتم-الأرجحيّة. المطلوب: كيف يطابق الطبيعي نيوتن؟ الحل: الخطوة 1: هنا $F = -\mathbb{E}[\nabla^2 \ell]$؛فالتدرّج الطبيعي = خطوة نيوتن في هذه الحالة بالذات. النتيجة: يطابق نيوتن. الربط للذكاء الاصطناعي: ربط بـ(ch29).

مثال (48.6-13): فائدة عمليّة المعطيات: شبكة عصبيّة عميقة. المطلوب: لماذا ليس الطبيعي أكثر شيوعاً؟ الحل: الخطوة 1: تقدير/عكس F لكلّ خطوة مكلف؛K-FAC/Adam حلول وسط. النتيجة: كلفة تقدير F. الربط للذكاء الاصطناعي: مقايضة حسابيّة.

مثال (48.6-14): ملاحظة هندسيّة المعطيات: F يحدّد المسافة بين التوزيعات. المطلوب: ماذا يعني ذلك للتدريب؟ الحل: الخطوة 1: المسافة $\frac{1}{2}\Delta\theta^\top F \Delta\theta$ تقيس كم تغيّر النموذج سلوكاً. النتيجة: مقياس التغيّر. الربط للذكاء الاصطناعي: ثبات التدريب.

مثال (48.6-15): خلاصة المطلوب: فائدة الهبوط الريمانيّ؟ الحل: الخطوة 1: خطوات أقلّ وأكثر استقراراً على الفضاءات المنحنية. النتيجة: أسرع وأثبت. الربط للذكاء الاصطناعي: تحسين مُوجَّه هندسيّاً.

أخطاء شائعة

- **نسيان عامل F^{-1}:** لا يصحّ استخدام ∇L مباشرة على المُشعّب الإحصائيّ.
- **الظنّ أنّ $F = I$ دائماً:** المقياس الفعليّ يغيّر الاتجاه والحجم.
- **إغفال عملية الإرجاع R:** قد يخرج θ من المُشعّب.
- **الظنّ أنّ الطبيعي أفضل دائماً:** تقدير F مكلف وقد لا يستحقّ.
- **الخلط بين التدرّج الطبيعي ونيوتن:** الطبيعي بمقياس فيشر، ونيوتن بمقياس هسه.

صياغة رسمية: تُفترض البيانات الباهتة ذات بُعدٍ عالٍ مركّزةً على متشعّب منخفض البُعد $\mathcal{M}$، والهدف تضمين $f : \mathcal{M} \to \mathbb{R}^d$ يحفظ البنية الجيوديسيّة:

$$d_{\mathcal{M}}(x, y) \;\approx\; \|f(x) - f(y)\|_g \tag{8.48}$$

جدول الرموز

الرمز	المعنى
$\mathcal{M}$	متشعّب البيانات الكامن
$d_{\mathcal{M}}$	المسافة الجيوديسيّة داخلياً
Isomap	تضمين بـMDS على الجيوديسيّات
$J(g, f)$	تشويه المسافة (stress)

الرسم

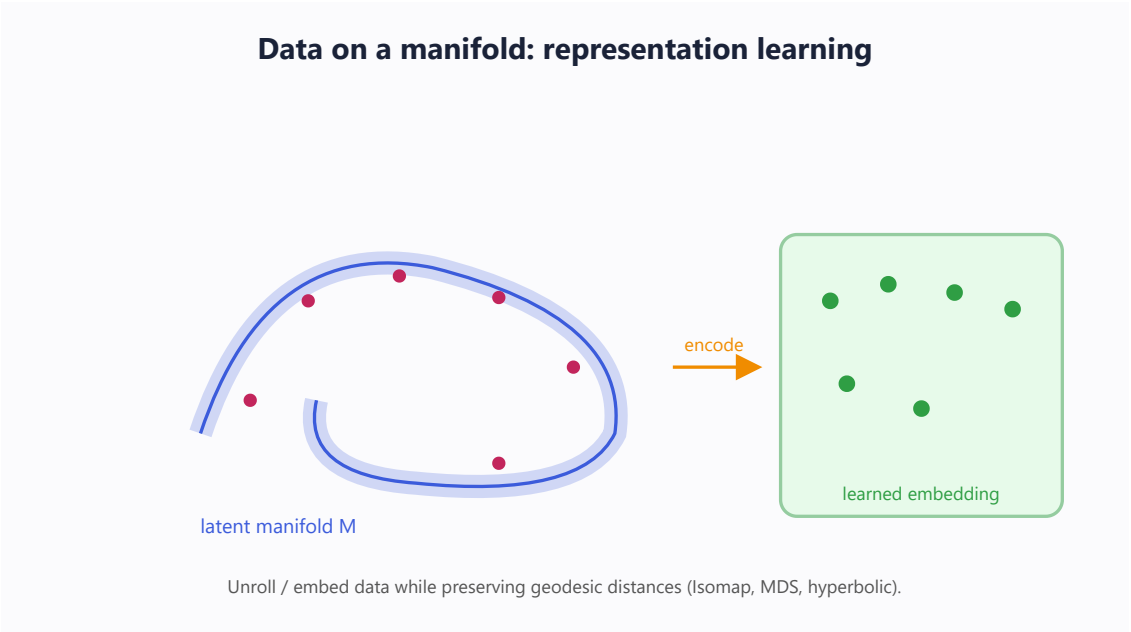
<figure> الشكل<figcaption> 6.48: بيانات على لولب (بُعد داخليّ 2)؛ التضمين يفتحها فتحاً يحفظ الجيوديسيّات.</figcaption> </figure>

البرهان

الخطوة 1 (فرضيّة المتشعّب): البيانات عالية الأبعاد لكنّها مولَّدة بعواملَ قليلة $\Rightarrow$ تقع قرب متشعّبٍ منخفض. ■

الخطوة 2 (Isomap): تُقدَّر الجيوديسيّات بالرسم البياني للجيران (ديكسترا) ثمّ يستهلكها MDS. ■

الخطوة 3 (التحقّق): يُقاس التشويه بمقاييس الإجهاد (stress) أو حفظ الجيران. ■



شكل ٦٠٤٨: *
التعلّم على المتشعّب

خمسة عشر مثالاً محلولاً

مثال (1-7.48): اللولب السويسريّ المعطيات: بيانات 3-أبعاد على لولب. المطلوب: البُعد الداخليّ. الحل: الخطوة 1: البُعد الداخليّ = 2 (سطح ملفوف)؛المحيط 3. النتيجة: 2. الربط بالذكاء الاصطناعي: تقليل البُعد.

مثال (2-7.48): جيوديسيّ مقابل إقليديّ المعطيات: نقطتان على دورتَي اللولب المتقابلتين. المطلوب: أيّ مسافة أصغر؟ الحل: الخطوة 1: أقصر طريق يتبع سطح اللولب، لا يقطع الهواء. النتيجة: الجيوديسيّ الطولي. الربط بالذكاء الاصطناعي: المسافة الحقيقيّة.

مثال (3-7.48): خطوات Isomap المعطيات: عيّنة على متشعّب. المطلوب: الخطوات الثلاث. الحل: الخطوة 1: بناء رسم الجيران؛ تقدير الجيوديسيّات؛ MDS. النتيجة: ثلاث خطوات. الربط للذكاء الاصطناعي: خوارزميّة قياسيّة.

مثال (4-7.48): رسم الجيران المعطيات: n نقطة؛نأخذ $k = 5$ جيران. المطلوب: عدد الحواف. الحل: الخطوة 1: نحو $\frac{nk}{2} = 2.5n$ حواف. النتيجة: $O(nk)$. الربط للذكاء الاصطناعي: تعقيد خطّيّ.

مثال (5-7.48): تشويه المسافة المعطيات: تشويهان $d_{data} = 1, d_{emb} = 2$. المطلوب: المساهمة في الإجهاد. الحل: الخطوة 1: $(2-1)^2/1^2 = 1$. النتيجة: 1. الربط للذكاء الاصطناعي: مقياس جودة.

مثال (6-7.48): إجهاد كليّ المعطيات: تشويهان 1 و25.0. المطلوب: J. الحل: الخطوة 1: $1 + 0.25 = 1.25$. النتيجة: 1.25. الربط للذكاء الاصطناعي: تقييم التضمين.

مثال (7-7.48): مسافة في قرص بوانكاريه المعطيات: $x = 0$، $y = (0.5, 0)$. المطلوب: d. الحل: الخطوة 1: $d = \operatorname{arcosh}(1 + \frac{2(0.25)}{(1)(0.75)}) = \operatorname{arcosh}(1.667) = \ln 3 \approx 1.099$. النتيجة: 1.099. الربط للذكاء الاصطناعي: هندسة قطعيّة.

مثال (8-7.48): نموّ الحجم في الفضاء القطعيّ المعطيات: قرص بوانكاريه؛ $V(r) = 2\pi(\cosh r - 1)$، $r = 2$. المطلوب: V ومقارنته بالإقليديّ. الحل: الخطوة 1: $V = 2\pi(3.762 - 1) = 2\pi(2.762) \approx 17.35$؛ الإقليديّ $\pi r^2 = 4\pi \approx 12.57$. النتيجة: القطعيّ أكبر. الربط للذكاء الاصطناعي: نموّ أُسّيّ للحجم.

مثال (9-7.48): عند نصف قطر أصغر المعطيات: $r = 1$. المطلوب: V ومقارنة. الحل: الخطوة 1: $V = 2\pi(1.543 - 1) = 2\pi(0.543) \approx 3.41$؛ الإقليديّ $\pi \approx 3.14$. النتيجة: متقاربان صغيراً. الربط للذكاء الاصطناعي: فرق قليل محليّاً.

مثال (10-7.48): تضمين الأشجار المعطيات: شجرة هرميّة. المطلوب: لماذا القطعيّ مناسب؟ الحل: الخطوة 1: حجم الأقراص ينمو أُسّياً فيه $\Rightarrow$ يشبه عدّ العقد في الأشجار. النتيجة: ملاءمة طبيعيّة. الربط للذكاء الاصطناعي: تضمينات هيبربوليّة.

مثال (11-7.48): تقدير البُعد الداخليّ المعطيات: كرة S^2؛عيّنة كثيفة. المطلوب: البُعد. الحل: الخطوة 1: تقدير محليّ للجيران يردّ 2. النتيجة: 2. الربط للذكاء الاصطناعي: تشخيص بيانات.

مثال (12-7.48): خرائط الانتشار المعطيات: عيّنة من توزيع كثافة. المطلوب: الفكرة. الحل: الخطوة 1: قيم ذاتيّة لمشغّل الانتشار تُعطي إحداثيّات تنظيم. النتيجة: تضمين طيفيّ. الربط للذكاء الاصطناعي: ربط بـ(3.48).

مثال (13-7.48): حفظ الجيران المعطيات: $k = 10$؛تقاطع الجيران قبل/بعد. المطلوب: المقياس. الحل: الخطوة 1: حفظ الجيران = $\|N(x) \cap N(f(x))\|/k$؛الأعلى أفضل. النتيجة: نسبة تقاطع. الربط للذكاء الاصطناعي: تقييم محلّيّ.

مثال (14-7.48): توافق التمثيلات المعطيات: نموذجان ومخرجات لكلّ. المطلوب: كيف نقارن؟ الحل: الخطوة 1: بتدوير/تحجيم المتشعّبين (محلّل محلّي/غوسيّ) حتّى يتوافقا. النتيجة: محاذاة. الربط للذكاء الاصطناعي: تفسير النماذج.

مثال (15-7.48): خلاصة المطلوب: ما المدلول الهندسيّ؟ الحل: الخطوة 1: التمثيل الجيّد يحافظ على الهندسة الكامنة لا الظرف المحيط. النتيجة: حفظ الهندسة. الربط للذكاء الاصطناعي: تعميم أفضل.

أخطاء شائعة

- **اعتماد مسافة إقليديّة بين نقاط على متشعّب ملتوٍ:** يخطئ في تقدير القرب.
- **إغفال اختيار k في رسم الجيران:** صغير يكسر الاتّصال، كبير يقارب الإقليديّ.
- **نسيان أنّ البُعد الداخليّ قد يقلّ كثيراً عن المحيط.**
- **الظنّ أنّ الفرعيّة (PCA) كافية:** تفشل في اللولب والمنحنيات.
- **إهمال قياس التشويه:** تضمين جميل قد يخرّب المسافات.

صياغة رسمية: عائلة التوزيعات $\{p_\theta\}$ متشعّبٌ إحصائيّ مُجهَّز بمقياس فيشر:

$$g_{ij}(\theta) = \mathbb{E}_\theta\big[\partial_i \ell \, \partial_j \ell\big] = -\mathbb{E}_\theta[\partial_i \partial_j \ell] \tag{9.48}$$

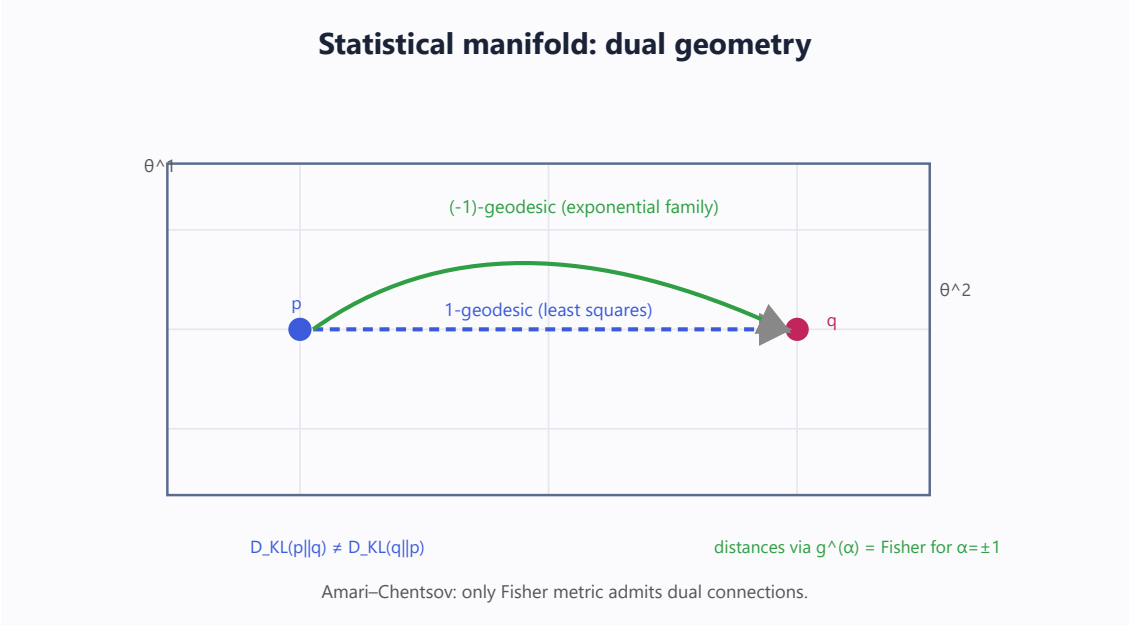
ولكلّ $\alpha \in \mathbb{R}$ اتصالٌ ثنائيّ $\nabla^{(\alpha)}$ مع $\nabla^{(-1)} = e$ و$\nabla^{(+1)} = m$؛ ونظريّة تشينتوف-أماري: مقياس فيشر هو المقياس الثابت الوحيد (حتى عدد).

جدول الرموز

الرمز	المعنى
e-geodesic	جيوديسيّ الاتّصال (-1) (خطّي في المتوسّط)
m-geodesic	جيوديسيّ الاتّصال $(+1)$ (خطّي في الوسيط)
D_{KL}	تباعد غير متماثل يحدّد الهندسة
g_{ij}	فيشر

الرسم

<figure> الشكل<figcaption> 7.48: متشعّب إحصائيّ؛ جيوديسيّ e (أخضر) وm (أزرق) بين توزيعين p, q؛



شكل ٧.٤٨: *
الهندسة الإحصائيّة

والمقياس مقياس فيشر.</figcaption> </figure>

البرهان

الخطوة 1 (المقياس): $D_{KL}(p_{\theta+d\theta}\|p_\theta) = \frac{1}{2} d\theta^\top g(\theta) d\theta + O(\|d\theta\|^3)$ $\Rightarrow$ المقياس من D_{KL} (مرتبطة بـch26). ■

الخطوة 2 (الاتّصالات الثنائيّة): $g(\nabla_X^{(\alpha)} Y, Z) + g(X, \nabla_Y^{(-\alpha)} Z) = 0$ $\Rightarrow$ لـe وm ازدواجيّة. ■

الخطوة 3 (فيترفورث): لكلّ زحف ريادي F، أوّل $\arg\min D_{KL}$؛والجمع D_{KL} يحقّق فيثاغورس على الاتّصال المزدوج. ■

خمسة عشر مثالاً محلولاً

مثال (1-8.48): مقياس برنولي المعطيات: عائلة برنولي بالوسيط p. المطلوب: g_p. الحل: الخطوة 1: $\ell = x \ln p + (1-x)\ln(1-p)$؛ $\partial_p \ell = x/p - 1/(1-p) = (x-p)/(p(1-p))$؛ $g_p = 1/(p(1-p))$. النتيجة: $1/(p(1-p))$.
الربط للذكاء الاصطناعي: يُطابق الـF في ch29.

مثال (2-8.48): قيمة عند $p = 0.5$ المعطيات: من (1-8.48). المطلوب: $g_{0.5}$. الحل: الخطوة 1: $1/(0.5 \times 0.5) = 4$. النتيجة: 4. الربط للذكاء الاصطناعي: أقصى حساسيّة عند الوسط.

مثال (3-8.48): قيمة عند $p = 0.9$ المطلوب: $g_{0.9}$. الحل: الخطوة 1: $1/(0.9 \times 0.1) = 11.11$. النتيجة: 11.11. الربط بالذكاء الاصطناعي: حساسيّة عالية قرب الحدّ.

مثال (4-8.48): عند $p = 0.25$ المطلوب: $g_{0.25}$. الحل: الخطوة 1: $1/0.1875 = 5.33$. النتيجة: $1/(0.25 \times 0.75)$. الربط للذكاء الاصطناعي: مقارنة نسبيّة.

مثال (5-8.48): غاوسيّ (متوسط فقط) المعطيات: $\mathcal{N}(\mu, \sigma^2)$؛ $\sigma = 1$. المطلوب: g_μ. الحل: الخطوة 1: $g_\mu = 1/\sigma^2 = 1$. النتيجة: 1. الربط للذكاء الاصطناعي: مقياس تباين.

مثال (48.8-6): غاوسيّ بتباينٍ 2 المطلوب: g_μ. الحل: الخطوة 1: $0.25 = 1/4$. النتيجة: 0.25. الربط للذكاء الاصطناعي: تباين أكبر $\Rightarrow$ مقياس أصغر.

مثال (48.8-7): غاوسيّ كامل (معاملان) المعطيات: (μ, σ)؛$\sigma = 1$. المطلوب: عناصر g. الحل: الخطوة 1: $g_{\mu\mu} = 1/\sigma^2 = 1$؛$g_{\sigma\sigma} = 2/\sigma^4 = 2$؛الخارجيّ 0. النتيجة: $\mathrm{diag}(1, 2)$. الربط للذكاء الاصطناعي: مصفوفة فيشر قُطريّة.

مثال (48.8-8): عدم تماثل D_{KL} المعطيات: $p = \mathrm{Bern}(0.5)$، $q = \mathrm{Bern}(0.9)$. المطلوب: $D_{KL}(p\|q)$. الحل: الخطوة 1: $0.5\ln(0.5/0.9) + 0.5\ln(0.5/0.1) = 0.5(-0.588) + 0.5(1.609) = -0.294 + 0.805 = 0.511$. النتيجة: 0.511. الربط للذكاء الاصطناعي: تباعد غير متماثل.

مثال (48.8-9): الاتجاه المعاكس المعطيات: $D_{KL}(q\|p)$ لـ $q = 0.9, p = 0.5$. المطلوب: القيمة ومقارنتها. الحل: الخطوة 1: $0.9\ln(0.9/0.5) + 0.1\ln(0.1/0.5) = 0.9(0.588) + 0.1(-1.609) = 0.529 - 0.161 = 0.368$. النتيجة: $0.511 \neq 0.368$. الربط للذكاء الاصطناعي: يؤكّد عدم التماثل.

مثال (48.8-10): تطابق للرتبة الثانية المعطيات: $D_{KL}(\theta \| \theta + d\theta)$. المطلوب: الشكل. الحل: الخطوة 1: $\frac{1}{2} d\theta^\top g(\theta) d\theta + O(\|d\theta\|^3)$. النتيجة: تربيعيّ + خطأ ثالث. الربط للذكاء الاصطناعي: التوسّع الرئيس.

مثال (48.8-11): جيوديسيّ e لبرنولي المعطيات: الاتّصال (-1). المطلوب: الشكل. الحل: الخطوة 1: خطّي في الوسيط $t \mapsto (1-t)p + tq$ (جيوديسيّ مختصر). النتيجة: مستقيم في الوسيط. الربط للذكاء الاصطناعي: مسار المزيج.

مثال (48.8-12): جيوديسيّ m لبرنولي المعطيات: الاتّصال $(+1)$. المطلوب: الشكل. الحل: الخطوة 1: خطّي في المعامل الطبيعي $\eta = \ln(p/(1-p))$؛يعطي مساراً منحنياً في p. النتيجة: مسار أُسّي. الربط بالذكاء الاصطناعي: مسار العائلة الأُسّيّة.

مثال (48.8-13): فيثاغورس المزدوج المعطيات: m-إسقاط p من q؛ثمّ e-إسقاط. المطلوب: المضمون. الحل: الخطوة 1: على الاتّصال المزدوج يتحقّق فيثاغورس: $D_{KL}(p\|r) = D_{KL}(p\|m) + D_{KL}(m\|r)$ إذا كان m هو m-إسقاط p. النتيجة: تجزئة ثابتة. الربط للذكاء الاصطناعي: أساس تقدير EM.

مثال (48.8-14): EM كإسقاطات e/m المعطيات: خطوة E ثمّ خطوة M. المطلوب: التفسير الهندسيّ. الحل: الخطوة 1: خطوة E = e-إسقاط؛خطوة M = m-إسقاط (يُقلّلان المطابقة تباعاً). النتيجة: مسار مزدوج. الربط للذكاء الاصطناعي: EM كجذب رادي (رابط ch18).

مثال (48.8-15): خلاصة المطلوب: ما الجوهر؟ الحل: الخطوة 1: الهندسة محكومة بمقياس فيشر؛ المسافات غير متماثلة؛ والاتّصال المزدوج يوحّد التطابق. النتيجة: هندسة واحدة للتعلّم. الربط بالذكاء الاصطناعي: خاتمة الفصل والكتاب.

أخطاء شائعة

- **الظنّ أنّ مقياس فيشر ثابت:** هو دالّة في θ؛لبرنولي يتغيّر اختلافاً بين الأطراف.
- **نسيان تعريف الارتباط:** $\nabla_X Y - \nabla_Y X = [X, Y]$ (بلا فتل).
- **الخلط بين e وm:** e خطيّة في الوسيط، m خطّيّة في المعلوم.
- **إغفال أن g تُحسب بالنسبة لمعاملات التوزيع:** تغيير التصوّر يُغيّر المقياس.

جدول تجميع النظريات

النظرية	العنوان	المعادلة المحوريّة	الرسم
2.48	المتشعّبات والمماسيّ	$T_pM \cong \mathbb{R}^n$	fig-4801
3.48	المقياس والجيوديسي	$ds^2 = g_{ij}dx^i dx^j$	fig-4802
4.48	ليفي-چيڤيتا والنقل	$\nabla_{\dot\gamma} V = 0$	fig-4803
5.48	الانحناء	$K = \frac{g(R(X,Y)Y,X)}{\cdot}$	fig-4804
6.48	التدرّج الطبيعي	$\tilde\nabla = F^{-1}\nabla L$	fig-4805
7.48	متشعّبات التمثيل	$d_{\mathcal{M}} \approx \|f(x) - f(y)\|$	fig-4806
8.48	الهندسة الإحصائيّة	$g_{ij} = \mathbb{E}[\partial_i \ell \partial_j \ell]$	fig-4807

عشرون تمريناً محلولاً (إجابات موجزة)

١. **(مماسيّ)** $\dim T_pM \Rightarrow M = S^2$ — 2.

٢. **(نورمال vs مماسيّ)** الشعاع الكرويّ عند القطب — نورماليّ (خارج المماسيّ).

٣. **(ضمنيّ)** $h = 0$ في $\mathbb{R}^3$ مع $\nabla h \neq 0$ — $\dim = 2$.

٤. **(مقياس)** $\|(3,4)\|_2$ — 5.

٥. **(قوس)** $R = 2$، $\Delta\theta = \pi/2$ — $\pi \approx 3.14$.

٦. **(قطبو-استواء)** $R = 1$ — $\pi/2 \approx 1.57$.

٧. **(مقياس قُطريّ)** $g = \mathrm{diag}(2,3)$، $v = (1,1)$ — $\sqrt{5}$.

٨. **(بوانكاريه)** $\|x\| = 0.5$ من 0 — $d = \ln 3 \approx 1.099$.

٩. **(بوانكاريه)** $\|x\| = 0.9$ من 0 — $d \approx 3.0$.

١٠. **(كرستوفل قطبيّ)** $r = 2$ — $\Gamma^r_{\theta\theta} = -2$، $\Gamma^\theta_{r\theta} = 0.5$.

١١. **(كرستوفل كرويّ)** $\theta = \pi/2$ — $\cot = 0$، $\Gamma^\theta_{\varphi\varphi} = 0$.

١٢. **(انحناء)** K لكرة $R = 2$ — 0.25.

١٣. **(سلّمي)** S^2 بنصف $S = 2$ — 1.

١٤. **(طبيعيّ)** $F = \mathrm{diag}(4,1)$، $\nabla L = (4,6)$ — $\tilde\nabla = (1,6)$.

١٥. **(غاوسيّ فيشر)** $\mu, \sigma = 1$ واحد — $F = 1$.

١٦. **(برنولي فيشر)** $p = 0.5$ — 4؛ $p = 0.9$ — 11.11.

١٧. **(KL غير متماثل)** 0.5 مقابل 0.9 — 0.511 عكس 0.368.

١٨. **(تشويه)** $d_{data} = 1, d_{emb} = 2$ — مساهمة 1.

١٩. **(حجم قطعيّ)** $V(2)$ مقابل πr^2 — 17.3 مقابل 12.6.

٢٠. **(خلاصة)** التدرّج الطبيعي لـ $F = 2I$، $\nabla L = (4,6)$ — $(2,3)$.

فهرس الرموز

الرمز	المعنى	أول ورود
M, T_pM	المتشعّب والمماسيّ	2.48
g, ds^2	المقياس الريمانيّ	3.48
Γ_{ij}^k	رموز كرستوفل	4.48
R, K, Ric	الانحناءات	5.48
$\bar{\nabla}$	التدرّج الطبيعي	6.48
$d_{\mathcal{M}}$	مسافة المتشعّب	7.48
g_{ij} (فيشر)	المقياس الإحصائيّ	8.48

المراجع

- M. J. Lee, (2018). *Riemannian Manifolds to Introduction*. Springer.
- M. Carmo, do (1992). *Riemannian Geometry*. Birkhäuser.
- S. Amari, (2016). *Information Geometry and Its Applications*. Springer.
- R. Sepulchre, R., Mahony, P.-A., Absil, (2008). *Matrix Manifolds on Algorithms Optimization*. Princeton.
- H. Narayanan, S., Mitter, C., Fefferman, (2016). *Testing the Manifold Hypothesis*. JASA.
- R. Henriques, et al. (2022). *Deep Learning and Information Geometry*. Springer (مقالات مرجعيّة).
- K. Cho, et al. (2019). *Large-Margin Classification in Hyperbolic Space*. NeurIPS.

القسم IX

المتسلسلات ومعالجة الإشارة

نبذة عن هذا الجزء

كلّ ما سبق من أجزاء تعامل مع البيانات بوصفها **متجهات في فضاء**: نقطاً، أو توزيعات، أو عقداً على رسم. لكنّ جزءاً واسعاً من العالم ليس كذلك: الصوتُ موجةٌ تتغيّر مع الزمن، والصورةُ إشارةٌ على بُعدين، والسلسلة الزمنيةُ متتاليةٌ لا تُفهم حدّاً حدّاً بل **بنيتها كلّها**. هذا الجزء يفتح تلك النافذة، ويبدأ من حيث ينبغي البدء: من **المتسلسلات** — متى يجوز أن نجمع ما لا نهاية له، وكيف نحوّل متتاليةً إلى دالة، ولماذا التقارب الموحّد هو الشرط الذي يجعل التقريب جديراً بالثقة. ثم يأتي التحول الأكبر في تاريخ الرياضيات التطبيقية: **تحويل فوريه** — أن تقرأ الإشارة نفسها بلغة التردّدات، فتصير عملياتٌ معقّدة في الزمن (الالتفاف، الترشيح، إعادة العيّنة) مجرد ضربٍ واقتطاع. وبعده **المويجات والتحليل الزمني-الترددي** حين لا تكفي التردّدات وحدها، و**معالجة الإشارة الحديثة** حيث تلتقي المرشّحات الكلاسيكية بالشبكات العميقة، ونختم بـ**آفاق حديثة**: معالجة الإشارة على الرسوم، والمؤثّرات العصبية الطيفية، والتمثيلات الضمنية. من يتقن هذا الجزء يمتلك اللغة التي تُكتب بها أغلبُ نماذج الصوت والصورة والزمن — ويفهم لماذا تعمل، لا أن تعمل فحسب. **فصول الجزء:** المتسلسلات والتقارب والدوال المولّدة · متسلسلة فوريه ونظرية التقريب · تحويل فوريه والعيّنات · التحليل الزمني-الترددي والمويجات · معالجة الإشارة الحديثة والتعلّم العميق على الإشارات · آفاق حديثة ومستقبلية.

فصول هذا الجزء

- **الفصل 49.** المتسلسلات: التقارب، المعايير، والدوال المولّدة
- **الفصل 50.** متسلسلة فوريه ونظرية التقريب
- **الفصل 51.** تحويل فوريه، العيّنات، ونظرية نيكويست–شانون
- **الفصل 52.** التحليل الزمني-الترددي والمويجات
- **الفصل 53.** معالجة الإشارة الحديثة والتعلّم العميق على الإشارات
- **الفصل 54.** آفاق حديثة: إشارة الرسوم، المؤثّرات العصبية، والتمثيلات الضمنية

المتسلسلات: التقارب، المعايير، والدوال المولّدة

الشعار: «اللامتناهي لا يُحصى عدداً، بل يُحاصَر بحدٍّ يقترب منه — وكلّ خوارزمية تتعلّم إنما تراهن على أن هذا الاقتراب يكفي.»

تمهيد قصصي للفصل: هل يكفي أن تقترب؟

تخيّل أنك درّبت شبكةً عميقة أسبوعاً كاملاً، ثم سألت زميلك: «هل سيصل التدريب إلى نهاية؟» فأجاب: «الخطأ ينقص في كل خطوة». تسأل: «وإلى أين ينتهي؟» فيقول: «إلى الصفر تقريباً». تسأل السؤال الحاسم: **«هل ينقص بسرعة تكفي لأن يتوقّف قبل أن ينفد الوقت والمال؟»**

هذا السؤال الثالث هو سؤال المتسلسلات. فالخطأ في خطوة التدريب n ليس إلا حدّاً a_n في متسلسلة، ومجموع ما ستبذله من حوسبة حتى النهاية هو $\sum a_n$. أن «تنقص الأخطاء» لا يعني أن مجموعها منتهٍ — فالمتسلسلة التوافقية $\sum 1/n$ تنقص حدودها إلى الصفر، ومع ذلك يتباعد مجموعها إلى ما لا نهاية: حوسبةٌ بلا نهاية، وفاتورةٌ بلا سقف. وعكسه صحيح أيضاً: حدودٌ لا تزول بسرعة مرئية قد يكون مجموعها منتهياً تماماً إذا كانت تسير على مقياس $1/n^2$.

لذا يفتتح هذا الفصل الجزء التاسع بهندسة اللامتناهي: متى يجوز أن نجمع ما لا نهاية له من الحدود؟ ومتى يجوز أن نبدّل الترتيب، وأن نفاضل وتكامل حدّاً بحدّ، وأن نستبدل متتاليةً بدالة؟ ثم نصل إلى الجسر الذي يربط كل ذلك بالذكاء الاصطناعي الحديث: **الدوال المولّدة** التي تحوّل علاقةً تكرارية إلى معادلة جبريّة، **والعموديّة** التي تحفظ الطاقة وتفتح الباب لتحويل فوريه في الفصول التالية.

القارئ الذي يتقن هذا الفصل سيقرأ الفصول 50–54 بوصفها تطبيقاتٍ لفكرة واحدة: **أن نكتب الشيء نفسه بلغةٍ أخرى — معاملاتٍ بدل قيم، وتردّداتٍ بدل زمن — فتصير المسألة العسيرة حساباً بسيطاً.**

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. اختيار **معيار التقارب** المناسب لمتسلسلة موجبة، ومعرفة متى يصمت المعيار $(L = 1)$.

٢. التمييز بين **التقارب المطلق والشرطي**، وإدراك خطر إعادة ترتيب المتسلسلات الشرطية في الحساب الموزَّع.

٣. حساب **نصف قطر التقارب** لمتسلسلة قوى، وربطه بصلاحية تقريب تايلور محلّياً.

٤. التحقّق من **التقارب الموحّد** بمعيار M، ومعرفة ما يحفظه الموحّد (الاستمرارية، التكامل، التفاضل) وما لا يحفظه النقطي.

٥. بناء **دالة مولّدة** لعلاقة تكرارية وحلّها للحصول على شكل مغلق (تحويل Z لاحقاً).

٦. استخدام **تجميع سيزارو وأبيل** لترويض المتسلسلات المتذبذبة، وربطهما بمتوسطات التدرّج.

٧. تطبيق **متفاوتة بيسل ومساواة بارسيفال** في فضاءات هيلبرت، تمهيداً لمتسلسلة فوريه.

المتطلبات المسبقة

الفصلان 7 و8 (النهايات والتقارب، التفاضل)، والفصل 10 (التكامل)، والفصل 2 (الفضاءات الداخلية والعموديّة).

خريطة الفصل

القسم	القانون/النظرية	عدد الأمثلة المحلولة
1.49	المتسلسلة والمجموع الجزئي: المفردات	—
2.49	**معايير التقارب للمتسلسلات الموجبة**	15
3.49	**التقارب المطلق والشرطي وإعادة الترتيب**	15
4.49	**متسلسلات القوى ونصف قطر التقارب**	15
5.49	**التقارب الموحّد ومعيار M**	15
6.49	**الدوال المولّدة والتحويلات الفرقية**	15
7.49	**نظرية أبيل وتجميع سيزارو**	15
8.49	**العموديّة: بيسل وبارسيفال**	15
9.49	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

Integral · Test Root · Test Ratio · Test Comparison · Test Convergence · Sum Partial · Series Rearrangement Riemann · Convergence Conditional · Convergence Absolute · Test Raabe · Test · M-test Weierstrass · Convergence Unfiorm · Convergence of Radius · Series Power · · Inequality Bessel · Summation Abel · Summation Cesàro · Z-transform · Function Generating Basis Orthonormal · Identity Parseval

المتسلسلة (Series) هي مجموعُ حدودِ متتالية، ويُقصد به **نهايةُ مجاميعها الجزئية** لا أكثر؛ فاللامتناهي ليس عملية جمعٍ تُنجز، بل حدٌّ نُحاصره.

$$\sum_{n=1}^{\infty} a_n \;=\; \lim_{N\to\infty} S_N, \qquad S_N = \sum_{n=1}^{N} a_n \tag{1.1.49}$$

الرمز	المعنى	بديل برمجي
a_n	الحدّ العام (term)	a[n]
S_N	المجموع الجزئيّ N (partial sum)	np.cumsum(a)[N-1]
$\sum a_n$	المتسلسلة = $\lim S_N$	np.sum(a[:N]) مع N كبير
R_N	الباقي بعد N: $R_N = \sum_{n>N} a_n$	خطأ القطع (truncation error)
L	نهاية معيار النسبة/الجذر	lim a[n+1]/a[n]
R	نصف قطر التقارب	نطاق صلاحية التقريب

شرط لازم أول: إذا تقاربت المتسلسلة فلا بدّ أن $a_n \to 0$. لكنّ العكس **غير صحيح**: $\sum 1/n$ يتباعد مع أن $1/n \to 0$ — وهذا بالضبط هو الفخّ الذي يقع فيه من يظنّ أن «تناقص الخطأ في كل خطوة» يكفي لضمان توقّف التدريب بتكلفة منتهية.

تمهيد استفهامي

مهندسٌ يضبط جدولَ تضاؤل معدّل التعلّم فيكتب $\alpha_n = \alpha_0/n$، وآخر يكتب $\alpha_n = \alpha_0/n^2$، وثالث يكتب $\alpha_n = \alpha_0\, 0.99^n$. كلّهم «يجعل معدّل التعلّم يتناقص» — فهل هم سواء؟ المسافة الكلّية التي سيقطعها المتجه في فضاء

المعاملات هي $\|\nabla\|\sum \alpha_n$: متى تكون منتهية (فيستقرّ النموذج) ومتى تكون غير منتهية (فيظلّ يهيم)؟ ومن يقرّر ذلك بلا حسابٍ للامتناهي؟

هذا هو سؤال معايير التقارب: **أداةٌ تحكم على المصير من شكل الحدّ العام، بلا حاجة إلى حساب المجموع نفسه.**

صياغة رسمية

ليكن $a_n \geq 0$. فإنّ:

$$0 \leq a_n \leq b_n,\ \sum b_n < \infty \implies \sum a_n < \infty \quad \text{(مقارنة)} \tag{1.2.49}$$

$$L = \lim_{n\to\infty} \frac{a_{n+1}}{a_n}: \quad L<1 \Rightarrow \text{تقارب}, \quad L>1 \Rightarrow \text{تباعد}, \quad L=1 \Rightarrow \text{غير حاسم} \quad \text{(نسبة، دالامبر)} \tag{2.2.49}$$

$$L = \lim_{n\to\infty} \sqrt[n]{a_n}: \quad L<1 \Rightarrow \text{تقارب}, \quad L>1 \Rightarrow \text{تباعد}, \quad L=1 \Rightarrow \text{غير حاسم} \quad \text{(جذر، كوشي)} \tag{3.2.49}$$

$$f \searrow 0,\ f(n)=a_n \implies \sum_{n=1}^{\infty} a_n < \infty \iff \int_1^{\infty} f(x)\,dx < \infty \quad \text{(تكاملي)} \tag{4.2.49}$$

$$\lim_{n\to\infty} n\left(\frac{a_n}{a_{n+1}}-1\right) = r: \quad r>1 \Rightarrow \text{تقارب}, \quad r<1 \Rightarrow \text{تباعد} \quad \text{(رابه)} \tag{5.2.49}$$

جدول الرموز

الرمز	المعنى	ملاحظة
a_n	الحدّ العام الموجب	$a_n \geq 0$
b_n	متسلسلة مرجعية معلومة	غالباً هندسية أو $1/n^p$
L	نهاية النسبة أو الجذر	$L=1$ يعني صمت المعيار
f	دالة متناقصة تمرّ بـa_n	للمعيار التكاملي
r	حدّ رابه	يعمل حيث يفشل النسبة $(L=1)$
p	أُسّ المقارنة في $\sum 1/n^p$	$p>1$ تقارب، $p\leq 1$ تباعد

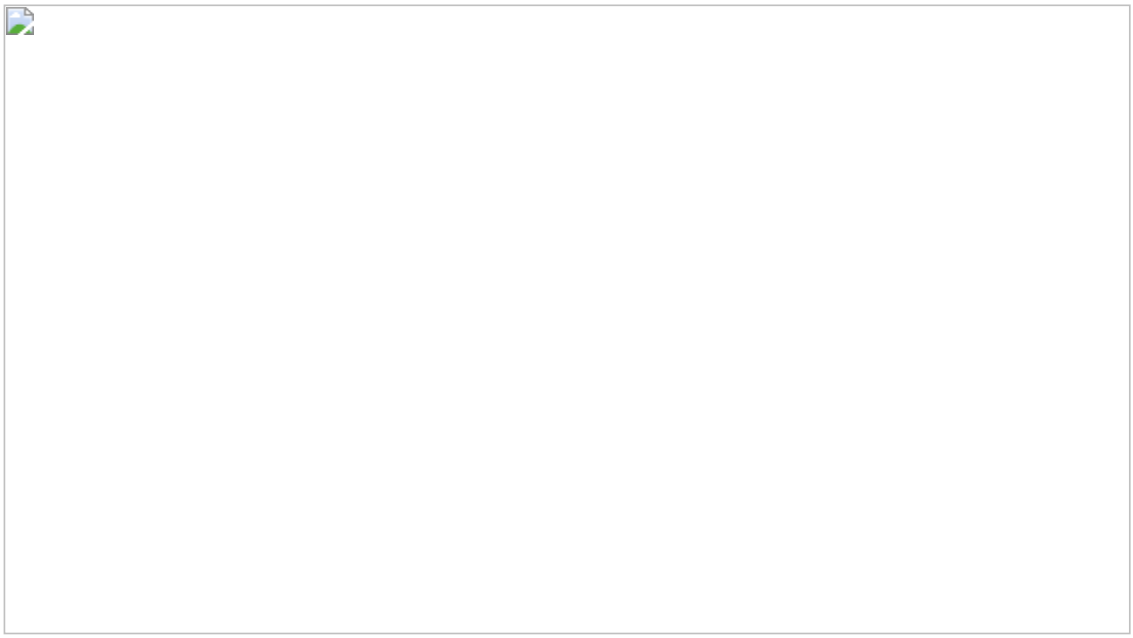
برهان (مخطط)

١. **(المقارنة)** المتسلسلة $S_N=\sum_{n\leq N} a_n$ رتيبة متزايدة (لأن $a_n\geq 0$)، ومحصورة فوق بـ$\sum b_n$؛ فتقترب بنظرية التقارب الرتيب (monotone convergence).

٢. **(النسبة)** إذا $L<q<1$ فـ$a_{n+1}\leq q\,a_n$ من رتبةٍ ما فصاعداً، فـ$a_n \leq Cq^n$: محصورة بمتسلسلة هندسية نابجة. وإن $L>1$ فالحدود لا تزول أصلاً فتتباعد بشرط الحدّ.

٣. **(الجذر)** من $\sqrt[n]{a_n}\leq q<1$ نجد $a_n\leq q^n$ مباشرةً. الجذر أقوى من النسبة: قد يوجد $\lim \sqrt[n]{a_n}$ حيث لا يوجد $\lim a_{n+1}/a_n$.

٤. **(التكاملي)** من تناقص f: $\int_n^{n+1} f \leq a_n \leq \int_{n-1}^{n} f$، وجمعُ المتراجحات يُحصر المجموع بين تكاملين.



شكل ١٠٤٩: *
شجرة معايير تقارب المتسلسلات الموجبة: المقارنة، النسبة، الجذر، والمعايير الاحتياطية عند L=1

٥. **(رابه)** يقارن a_n بمتسلسلة $1/n^s$ اختيارُها من سلوك النسبة عند $L=1$: فإذا $n(a_n/a_{n+1}-1)\to r>1$ فـ$a_n \le C/n^s$ ببعض $1<s<r$. ■

شروط الصحّة: المعايير (1.2.49–5.2.49) تفترض إيجاب الحدود، وللمتسلسلات المتناوبة نحتاج معايير أخرى (القسم 3.49). والمعيار التكاملي يشترط **تناقصاً رتيباً**، لا مجرد تناقصٍ في النهاية.

أمثلة محلولة (15)

مثال (1-2.49): متسلسلة هندسية — تضاؤل أُسّي لمعدّل التعلّم

المعطيات: $a_n=(1/2)^n$، والمطلوب: هل $\sum a_n$ منتهٍ؟ وقيمته؟ الحل: الخطوة 1: نسبةُ الحدود $\frac{a_{n+1}}{a_n}=\frac{1}{2}=L<1\Rightarrow$ تقارب بمعيار النسبة. الخطوة 2: المجموع الهندسي: $\sum_{n\ge1}(1/2)^n=\frac{1/2}{1-1/2}=1$. النتيجة: المجموع $=1$ منتهٍ تماماً. الربط بالذكاء الاصطناعي: التضاؤل الأُسّي $\alpha_n=\alpha_0\gamma^n$ يضمن مسافةً كلّية منتهية $\alpha_0\gamma/(1-\gamma)$: النموذج يستقرّ.

مثال (2-2.49): $\sum 1/n^2$ — التضاؤل التربيعي

المعطيات: $a_n=1/n^2$. الحل: الخطوة 1: معيار النسبة يعطي $L=\lim\frac{n^2}{(n+1)^2}=1$: يصمت. الخطوة 2: المعيار التكاملي: $\int_1^\infty x^{-2}dx=[-x^{-1}]_1^\infty=1<\infty$. الخطوة 3: إذن المتسلسلة تقارب (وقيمتها $\pi^2/6$ شهيرة). النتيجة: تقارب، والمجموع ≈ 1.645. الربط بالذكاء الاصطناعي: جدول Robbins–Monro $\alpha_n=\alpha_0/n^2$ المعدّل) يضمن حركةً كلّية منتهية، بخلاف $1/n$.

مثال (2.49-3): المتسلسلة التوافقية — التضاؤل البطيء القاتل

المعطيات: $a_n = 1/n$، والمطلوب: مجموعُها؟ الحل: الخطوة 1: النسبة $L = 1$ تصمت، الجذر كذلك. الخطوة 2: التكامل: $\int_1^\infty \frac{dx}{x} = [\ln x]_1^\infty = \infty \Rightarrow$ تباعد. النتيجة: تباعد، وإن كان ببطءٍ شديد ($S_N \approx \ln N + 0.577$). الربط بالذكاء الاصطناعي: $\alpha_n = \alpha_0/n$ تعني حركةً كلّية غير منتهية: النموذج لا يستقرّ أبداً، وإن تباطأ.

مثال (2.49-4): $\sum 1/(n\ln^2 n)$ — حدودٌ أبطأ من أيّ أُسّ

المعطيات: $a_n = \frac{1}{n(\ln n)^2}$ $(n \geq 2)$. الحل: الخطوة 1: التكامل بالتعويض $u = \ln x$ $:= \int_2^\infty \frac{dx}{x(\ln x)^2}$ $\int_{\ln 2}^\infty u^{-2}du = \frac{1}{\ln 2} < \infty$. النتيجة: تقارب، مع أن حدودها أكبر من $1/n^{1+\varepsilon}$ لأيّ ε صغير في النهاية. الربط بالذكاء الاصطناعي: مثالٌ تحذيري: «الأكبر من متسلسلة متقاربة» لا يعني التباعد — لا استنتاج دون معيار.

مثال (2.49-5): $\sum n/2^n$ — أُسّيّ يهزم كثيرَ حدود

المعطيات: $a_n = n/2^n$. الحل: الخطوة 1: النسبة: $1 < \frac{1}{2} \leftarrow \frac{n+1}{2n} = \frac{a_{n+1}}{a_n} \Rightarrow$ تقارب. الخطوة 2: القيمة: $\sum nx^n = x/(1-x)^2$ عند $x = 1/2 \Rightarrow 2$. النتيجة: تقارب، والمجموع $= 2$. الربط بالذكاء الاصطناعي: متوقّعُ عمقِ عقدةٍ في شجرة بحث عشوائي، ومتوقّعُ عددِ الخطوات قبل التوقّف: كلاهما من هذا القبيل.

مثال (2.49-6): $\sum 2^n/n!$ — حصرُ مقامِ softmax

المعطيات: $a_n = 2^n/n!$. الحل: الخطوة 1: النسبة: $1 > 0 \leftarrow \frac{2}{n+1} = \frac{a_{n+1}}{a_n} \Rightarrow$ تقارب سريع. الخطوة 2: المجموع $e^2 - 1 \approx 6.389$ (من متسلسلة الأُسّ). النتيجة: تقارب مطلق سريع. الربط بالذكاء الاصطناعي: مقامات softmax والتوزيعات الأُسّية تقاربها مضمونٌ بسرعةٍ أُسّية — أساس استقرار حصرِ المقام عدديّاً.

مثال (2.49-7): $\sum \left(\frac{n}{2n+1}\right)^n$ — معيار الجذر

المعطيات: $a_n = \left(\frac{n}{2n+1}\right)^n$. الحل: الخطوة 1: الجذر: $1 > \frac{1}{2} \leftarrow \frac{n}{2n+1} = \sqrt[n]{a_n} \Rightarrow$ تقارب بمعيار الجذر. الخطوة 2: (مع النسبة أيضاً يعطي $1/2$، لكنّ الجذر أقلّ حساباً هنا.) النتيجة: تقارب. الربط بالذكاء الاصطناعي: الحدود ذات الشكل «قوة تساوي الرتبة» تُقرأ بالجذر مباشرةً، وتظهر في حدود الاستقرار لطبقاتٍ متكرّرة.

مثال (2.49-8): $\sum 1/n!$ — متسلسلة الأُسّ

المعطيات: $a_n = 1/n!$. الحل: الخطوة 1: النسبة $0 \leftarrow \frac{1}{n+1} = \Rightarrow =$ تقارب. الخطوة 2: $e = \sum_{n\geq 0} 1/n!$. النتيجة: تقارب والمجموع e. الربط بالذكاء الاصطناعي: تظهر في نواة بواسون، وفي تقريبات توزيعات العدّ في النماذج التوليدية.

مثال (2.49-9): معيار p: متى يتقارب $\sum 1/n^p$؟

المعطيات: $a_n = n^{-p}$، $p > 0$. الحل: الخطوة 1: التكامل: $\int_1^\infty x^{-p}dx = \left[\frac{x^{1-p}}{1-p}\right]_1^\infty$ منتهٍ $p > 1$. الخطوة 2: عند $p = 1$ يتباعد لوغاريتمياً، وعند $p < 1$ يتباعد أسرع. النتيجة: تقارب $\iff p > 1$. الربط بالذكاء الاصطناعي: قانون الطاقة: «ذيل التوزيع $1/n^p$ بمعنىً محدود» شرطُه $p > 1$ — شرطُ وجودِ متوقّعٍ منتهٍ في توزيعات الذيل الثقيل.

مثال (2.49-10): $\sum 1/(n\ln n)$ — خطوة واحدة تُحدث الفرق

المعطيات: $a_n = \frac{1}{n\ln n}$ $(n \geq 2)$. الحل: الخطوة 1: التكامل: $\int_2^\infty \frac{dx}{x\ln x} = [\ln\ln x]_{\ln 2}^\infty = \infty$. النتيجة: تباعد — بخلاف المثال (2.49-4) الذي زاد لوغاريتمًا واحداً في المقام. الربط بالذكاء الاصطناعي: الحساسيّة الدقيقة لجداول التضاؤل: إضافةُ لوغاريتمٍ واحد قد تفصل بين الاستقرار وعدمه.

مثال (2.49-11): $\sum(\ln n)/n^2$ — اللوغاريتم أضعف من أيّ أُسّ

المعطيات: $a_n = (\ln n)/n^2$. الحل: الخطوة 1: نقارن: $\ln n \leq n^{1/2}$ من رتبةٍ ما $\Rightarrow a_n \leq n^{-3/2}$. الخطوة 2: $\sum n^{-3/2}$ متقاربة $(p = 3/2 > 1) \Rightarrow$ المتسلسلة الأصلية متقاربة بالمقارنة. النتيجة: تقارب. الربط بالذكاء الاصطناعي: العوامل اللوغاريتمية لا تُفسد تقارباً أُسّيّاً — تُفسده فقط عند الحدود $(p = 1)$.

مثال (2.49-12): $\sum 1/(n^2+1)$ — مقارنة مباشرة

المعطيات: $a_n = 1/(n^2+1)$. الحل: الخطوة 1: $0 < a_n < 1/n^2$ و$\sum 1/n^2$ متقاربة $\Rightarrow$ المتسلسلة متقاربة بالمقارنة. النتيجة: تقارب (وقيمتها $\frac{\pi\coth\pi - 1}{2} \approx 1.077$). الربط بالذكاء الاصطناعي: نواظمُ التخميد $(w^2 + \lambda)$ تضمن تقارباً من هذا النوع في حدود التنظيم.

مثال (2.49-13): معيار رابه حيث تصمت النسبة

المعطيات: $a_n = \frac{(2n)!}{(n!)^2 4^n} \sim \frac{1}{\sqrt{\pi n}}$. الحل: الخطوة 1: النسبة: $\frac{a_{n+1}}{a_n} = \frac{2n+1}{2n+2} \to 1 \Rightarrow$ المعيار يصمت. الخطوة 2: رابه: $n\left(\frac{a_n}{a_{n+1}} - 1\right) = n\left(\frac{2n+2}{2n+1} - 1\right) = \frac{n}{2n+1} \to \frac{1}{2} < 1 \Rightarrow$ تباعد. النتيجة: تباعد (واتفاقه مع السلوك $1/\sqrt{n}$ الذي يتباعد). الربط بالذكاء الاصطناعي: معاملات ذيول التوزيعات المركزية (مثل binomial تُقاس بهذا المقياس الدقيق لتحديد سلوك الذيل.

مثال (2.49-14): تكاثف كوشي — ضغط المتسلسلة

المعطيات: $a_n = \frac{1}{n(\ln n)(\ln\ln n)^2}$. الحل: الخطوة 1: a_n متناقصة $\Rightarrow$ نطبّق تكاثف كوشي: $\sum a_n$ تكافئ $\sum 2^k a_{2^k}$. الخطوة 2: $2^k a_{2^k} = \frac{1}{k(\ln k)^2} \cdot \frac{2^k}{2^k}/(\ln 2) \asymp \frac{1}{k(\ln k)^2}$ وهي متقاربة (كمثال 2.49-4). النتيجة: المتسلسلة الأصلية متقاربة. الربط بالذكاء الاصطناعي: تكاثف كوشي هو الفكرة نفسها خلف «تجميع المقاييس»

multi-scale) (pooling في الشبكات الالتفافية.

مثال (49.2-15): ميزانية حوسبة التدريب

المعطيات: تكلفة الخطوة n هي $c_n = C/n^2$ وحدة حوسبة، والمطلوب: هل الميزانية الكلّية منتهية؟ الحل: الخطوة 1: المجموع $\sum C/n^2 = C\pi^2/6 \approx 1.645C$. الخطوة 2: لو كانت $c_n = C/n$ لكان المجموع غير منته: لا ميزانية تكفي. النتيجة: بـ $p = 2$ الميزانية $p = 1$ وبـ $1.645C \approx$ غير منتهية. الربط بالذكاء الاصطناعي: هذه هي الصياغة الرياضية لسؤال «هل سينتهي التدريب؟»: تحويلُه إلى سؤال عن تقارب متسلسلة موجبة.

أخطاء شائعة

١. **الخلط بين $a_n \to 0$ وتقارب المتسلسلة:** الأول شرطٌ لازم لا كافٍ (المتسلسلة التوافقية شاهدٌ دائم).

٢. **تطبيق معايير الموجبة على متسلسلة متناوبة:** النسبة/الجذر/التكامل تفترض $a_n \geq 0$؛ للمتناوبة استخدم معيار لايبنتس أو اختبر التقارب المطلق.

٣. **الاستنتاج عند $L = 1$:** معيار النسبة/الجذر يصمت؛ لا حكم هناك — انتقل إلى رابه أو التكامل أو المقارنة.

٤. **نسيان الرتابة في المعيار التكاملي:** التناقص شرطٌ جوهري، لا تحسينٌ اختياري.

٥. **الظنّ أن تبادُل الحدود مسموح دائماً:** الترتيب يهمّ في المتسلسلات الشرطية (القسم التالي).

تمهيد قصصي

فريقٌ يدرّب نموذجاً على ثماني بطاقات رسومية، ويجمع التدرّجات من البطاقات كل خطوة. النتائج تتكرّر لكنّها لا تتطابق: فرقٌ صغير يتنقّل بين التشغيلات. ظنّوا خللاً في العتاد، ثم اكتشفوا أن ترتيب وصول التدرّجات إلى عقدة التجميع يتغيّر كل مرّة — وجمعُ أعداد الفاصلة العائمة **عملية غير تجميعية** أصلاً.

ثم جاء السؤال الأعمق: هل يكفي أن نجعل الترتيب ثابتاً؟ الجواب: **ليس دائماً**. فهناك متسلسلات «شرطية» — مجموعها موجود، لكن إعادة ترتيب حدودها قادرة على إنتاج **أيّ رقم تختاره**: صفر، أو مليون، أو ما لا نهاية. ومبرهنة ريمان تقول إن المتسلسلة الشرطية ليست «رقماً» بل **لعبة ترتيب**. فالشرط الذي يجعل مجموعك آمناً من ترتيب الحواسيب وتوزيعها ليس «أن يتقارب»، بل أن يتقارب **مطلقاً**.

صياغة رسمية

تُسمى المتسلسلة $\sum a_n$ **مطلقة التقارب** إذا $\sum |a_n| < \infty$. ويقع:

$$\sum |a_n| < \infty \implies \sum a_n \text{ متقاربة، وكلّ إعادة ترتيب } \sum a_{\sigma(n)} \text{ تعطي المجموع نفسه} \tag{1.3.49}$$

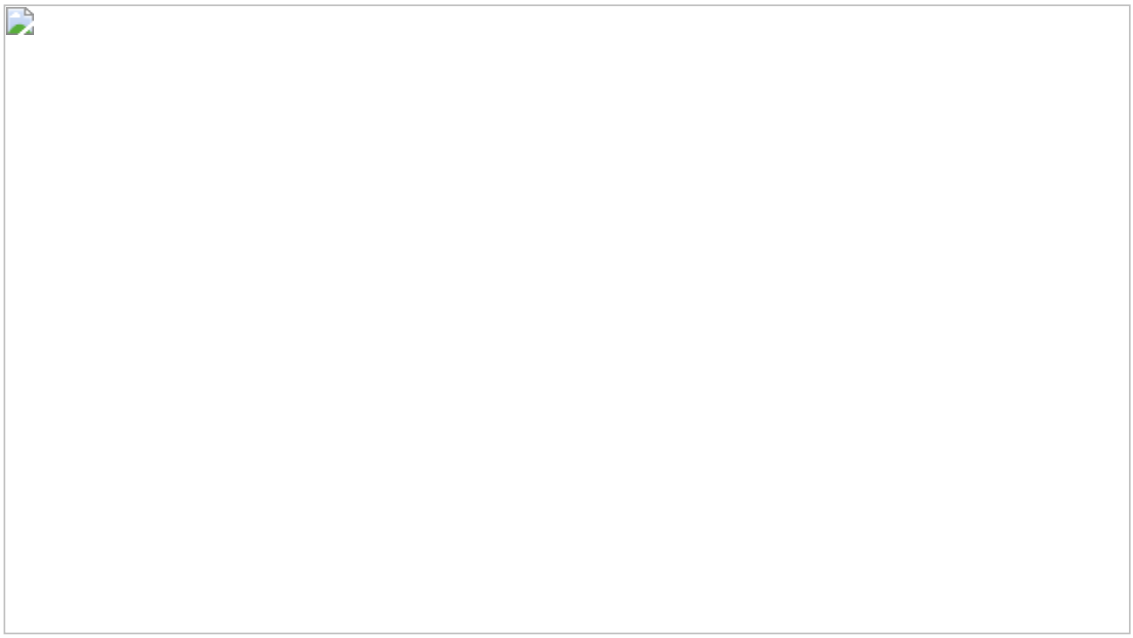
$$a_n \searrow 0 \implies \sum_{n=1}^{\infty} (-1)^{n+1} a_n \text{ متقاربة، و } |R_N| \leq a_{N+1} \quad \text{(لايبنتس)} \tag{2.3.49}$$

$$\forall S \in \overline{\mathbb{R}}\ \exists \sigma : \sum a_{\sigma(n)} = S \quad \Rightarrow \quad \sum a_n \text{ شرطية} \qquad \text{(ريمان في إعادة الترتيب)} \tag{3.3.49}$$

$$\sum b_n c_n \text{ متقاربة} \quad \Longleftarrow \quad c_n \searrow 0 \text{ محدودة، } A_N = \sum_{n \le N} b_n \qquad \text{(ديريكلِه)} \tag{4.3.49}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$\sum \|a_n\|$	متسلسلة القيم المطلقة	معيار التقارب المطلق
σ	تبديل (permutation) على الفهارس	ترتيب الحدود
R_N	الباقي بعد N	$\|R_N\| \le a_{N+1}$ عند لايبنتس
b_n, c_n	حدود معيار ديريكلِه	مجاميع b محدودة وc متناقصة
S	الهدف في إعادة الترتيب	يُمكن بلوغه بأيّ قيمة



شكل ٢.٤٩: *
التقارب المطلق مقابل الشرطي: تأثير إعادة الترتيب على المجموع

برهان (مخطط)

١. **(1.3.49)** من $|a_n|$-المتسلسلة المتقاربة والمقارنة: $\left|\sum_{n>N} a_n\right| \le \sum_{n>N} |a_n| \to 0$. ولأن إعادة الترتيب تحفظ مجاميع الحدود الموجبة (نظرية التقارب الرتيب)، فالمجموع واحد لأيّ ترتيب.

٢. **(2.3.49 لايبنتس)** المجاميع الجزئية الزوجية متناقصة والفردية متزايدة، والفرق بينهما $a_{N+1} \to 0 \Rightarrow$ تتلاقيان إلى حدٍّ واحد، والباقي محصور بالحدّ التالي.

٣. **(3.3.49 ريمان)** لأن $\sum a_n^+ = \infty$ و$\sum a_n^- = -\infty$ مع $a_n^{\pm} \to 0$، نجمع من الموجب حتى نتجاوز الهدف S، ثم من السالب حتى نهبط دونه، وهكذا؛ واتساع التأرجح يزول لأن الحدود تزول.

٤. **(4.3.49 ديريكلِه)** تجزئة أبيل (summation by parts): $\sum b_n c_n = A_N c_N + \sum_{n<N} A_n (c_n - c_{n+1})$، والمجاميع محدودة والتغيرات موجبة مجموعها منتهٍ. ■

شروط الصحّة: مبرهنة ريمان تتطلّب تقارباً شرطياً حقيقياً (لا مطلقاً). ومعايير لايبنتس وديريكلِه تعطي تقارباً قد يكون شرطياً — فلا تُستخدم وحدها لتبرير تبديل حدود أو تبديل جمعٍ بتكامل.

أمثلة محلولة (15)

مثال (3.49-1): المتسلسلة المتناوبة التوافقية

المعطيات: $\sum (-1)^{n+1}/n$. الحل: الخطوة 1: $0 \searrow 1/n$ a_n ⇒ تقارب بمعيار لايبنتس. الخطوة 2: $\sum |(-1)^{n+1}/n| = \sum 1/n$ تتباعد ⇒ التقارب شرطي. النتيجة: تقارب شرطي، ومجموعه $\ln 2$. الربط بالذكاء الاصطناعي: مثالٌ أول على أن «التقارب» لا يكفي للأمان العددي.

مثال (3.49-2): إعادة ترتيب تعطي نصف المجموع

المعطيات: $\ln 2 = 1 - \frac{1}{2} - \frac{1}{4} + \frac{1}{3} - \frac{1}{6} - \frac{1}{8} + \cdots$. الحل: الخطوة 1: نرتب: $1 - \frac{1}{2} + \frac{1}{3} - \frac{1}{4} + \cdots$ (موجب ثم سالبَين). الخطوة 2: المجموع $\frac{1}{2}\ln 2 = \frac{1}{2}\left(1 - \frac{1}{2} + \frac{1}{3} - \cdots\right)$. النتيجة: المجموع تغيّر إلى $\frac{1}{2}\ln 2$ بترتيبٍ آخر. الربط بالذكاء الاصطناعي: هذا هو سببُ اختلاف نتائج التدريب الموزَّع عند تغيّر ترتيب التجميع في المتسلسلات غير المطلقة.

مثال (3.49-3): استهدافُ قيمةٍ معيّنة بإعادة الترتيب

المعطيات: المتسلسلة السابقة، والهدف $S = 10$. الحل: الخطوة 1: نجمع من الحدود الموجبة $(1, \frac{1}{3}, \frac{1}{5}, \dots)$ حتى نتجاوز 10. الخطوة 2: نضيف سالباً واحداً فنهبط تحت 10، ثم نتابع بالموجبة... الخطوة 3: سعة التأرجح $\to 0$ لأن الحدود $\to 0$ ⇒ المجموع $\to 10$. النتيجة: أيّ هدف يمكن بلوغه بترتيبٍ مناسب. الربط بالذكاء الاصطناعي: تحذيرٌ مباشر: لا تبنِ قراراً على مجموع متسلسلة شرطية محسوبة بترتيبٍ عشوائي.

مثال (3.49-4): $\sum (-1)^n/n^2$ — متقاربة مطلقاً

المعطيات: $a_n = (-1)^n/n^2$. الحل: الخطوة 1: $\sum |a_n| = \sum 1/n^2 < \infty$ ⇒ تقارب مطلق. النتيجة: المجموع $= -\pi^2/12$، ثابتٌ لأيّ ترتيب. الربط بالذكاء الاصطناعي: التقارب المطلق يمنحك «رقماً» لا «لعبة ترتيب» — وهو المطلوب في كل تقديرٍ إحصائي.

مثال (3.49-5): $\sum \sin n/n$ مع معيار ديريكلِه

المعطيات: $b_n = \sin n$، $c_n = 1/n$. الحل: الخطوة 1: المجاميع الجزئية $\sum_{n \le N} \sin n = \frac{\sin(N/2)\sin((N+1)/2)}{\sin(1/2)}$ محدودة (بالصيغة المثلثية). الخطوة 2: $0 \searrow 1/n$ c_n ⇒ تقارب بمعيار ديريكلِه. النتيجة: تقارب (شرطي؛ إذ $\sum |\sin n|/n$ تتباعد). الربط بالذكاء الاصطناعي: يُبرّر تقارب متسلسلات الترشيح ذات النوى المتذبذبة عبر

الترددات.

مثال (3.49-6): لايبنتس وخطأ القطع

المعطيات: نريد $\sum (-1)^{n+1}/n^2$ بخطأ $< 10^{-3}$. الحل: الخطوة 1: $|R_N| \le a_{N+1} = 1/(N+1)^2$. الخطوة 2: نطلب $1/(N+1)^2 < 10^{-3} \Rightarrow N+1 > 31.6 \Rightarrow N = 31$. النتيجة: 31 حدّاً تكفي. الربط بالذكاء الاصطناعي: تقدير الباقي يعطي ميزانيةً حاسوبيّة قبل التنفيذ — لا بعده.

مثال (3.49-7): توقّعُ متغيّرٍ عشوائي وتقارب مطلق

المعطيات: X قيمه x_n باحتمالات p_n، والمطلوب: متى يُكتب $\mathbb{E}[X] = \sum x_n p_n$؟ الحل: الخطوة 1: الشرط الرياضي هو $\sum |x_n| p_n < \infty$ (تقارب مطلق). الخطوة 2: بدونه قد يكون «المتوقّع» غير محدّد أو يعتمد على الترتيب (مثل توزيع كوشي). النتيجة: التقارب المطلق هو شرطُ تعريف المتوقّع لا شرطَ حسابه فقط. الربط بالذكاء الاصطناعي: «لماذا لا ينفع متوسّط العيّنات في التوزيعات ثقيلة الذيل»: لأن المتوقّع غير موجود أصلاً.

مثال (3.49-8): تبديل الجمع والتكامل

المعطيات: هل يجوز $\int \sum f_n = \sum \int f_n$؟ الحل: الخطوة 1: يجوز إذا $\sum \int |f_n| < \infty$ (تقارب مطلق — مبرهنة فوبيني/تونيلّي). الخطوة 2: بدون الشرط قد يختلف الطرفان. النتيجة: الشرط هو التقارب المطلق لمتسلسلة التكاملات. الربط بالذكاء الاصطناعي: تبديل «توقّع» مع «جمع على الدفعات» في حدود التعميم يحتاج هذا الشرط بالضبط.

مثال (3.49-9): متسلسلة إشارات عشوائية (راديماخر)

المعطيات: $\varepsilon_n \in \{\pm 1\}$ عشوائية مستقلة، $a_n = 1/n$. الحل: الخطوة 1: $\sum |a_n| = \infty \Rightarrow$ التقارب المطلق مفقود. الخطوة 2: لكن $\sum \varepsilon_n a_n$ تتقارب شبهَ مؤكّد (لأن $\sum a_n^2 < \infty$ — نظرية كولموغوروف ثلاثية المتسلسلة). النتيجة: تقاربٌ شرطي لكنه مستقرّ بالمعنى الاحتمالي. الربط بالذكاء الاصطناعي: أساسُ حدود راديماخر (الفصل 31): تعقيد العائلة يُقاس بمتوسّط اضطراب الإشارات العشوائية.

مثال (3.49-10): أثرُ ترتيب جمع الفاصلة العائمة

المعطيات: جمع 10^6 حدّاً من مقادير 10^{-3} مع حدّ واحد 10^6 =. الحل: الخطوة 1: الجمع التصاعدي يفقد الحدود الصغيرة (استيعاب)، والتنازلي يحتفظ بها. الخطوة 2: الخطأ الكلّي يتراكم كمتسلسلة أخطاء قد تكون شرطية. النتيجة: الفرق بين الترتيبين قد يصل إلى $10^3 \approx$ وحدة. الربط بالذكاء الاصطناعي: الجمع الهرميّ (tree reduction) والتجميع بـKahan من الوسائل الهندسية لترويض هذا الأثر.

مثال (49.3-11): لايبنتس في متسلسلة خسارة متناوبة

المعطيات: خسارةٌ تتأرجح: $\ell_n = (-1)^n/n + \ell^\star$. الحل: الخطوة 1: المتسلسلة المتناوبة تقترب من $\ell^\star$ بخطأ $\le 1/(n+1)$. الخطوة 2: متوسّط القيم $\frac{1}{N}\sum \ell_n \to \ell^\star$ أسرع (ترويض سيزارو — القسم 7.49). النتيجة: المتوسط أفضل من الحدّ الأخير عند وجود تذبذب. الربط بالذكاء الاصطناعي: هذا هو التبرير الرياضي لـ«متوسط الأوزان» EMA) / model soup) لا مجرّد حيلة تجريبية.

مثال (49.3-12): متسلسلة هندسية بترتيب عشوائي

المعطيات: $\sum 2^{-n}$ بأيّ تبديل σ. الحل: الخطوة 1: التقارب مطلق $(\sum |2^{-n}| = 1 < \infty)$. الخطوة 2: إذن $\sum 2^{-\sigma(n)} = 1$ لكلّ σ. النتيجة: الترتيب لا يؤثّر البتّة. الربط بالذكاء الاصطناعي: المتسلسلات المطلقة هي الوحيدة الصالحة للحوسبة الموزَّعة غير الحتمية.

مثال (49.3-13): اختبار عملي للشرطيّة

المعطيات: متسلسلة محسوبة رقمياً بمجموعين مختلفي الترتيب يعطيان 0.693 و0.347. الحل: الخطوة 1: الفرق كبير $\Rightarrow$ اشتباه بتقارب شرطي. الخطوة 2: اختبر $\sum |a_n|$ عددياً: يتباعد $\Rightarrow$ الحكم مؤكّد. النتيجة: المتسلسلة شرطية، ولا يجوز الاعتماد على ترتيب الحساب. الربط بالذكاء الاصطناعي: اختبار تشخيصي رخيص لأي مسار تجميع موزّع.

مثال (49.3-14): متسلسلة القوى على الحدّ

المعطيات: $\sum (-1)^n x^n/n$ عند $x = 1$ وعند $x = -1$. الحل: الخطوة 1: عند $x = 1$: متناوبة توافقية $\Rightarrow$ تقارب شرطي (المجموع $-\ln 2$). الخطوة 2: عند $x = -1$: $\sum 1/n \Rightarrow$ تباعد. النتيجة: الحدّ $|x| = 1$ يُدرس نقطةً نقطة — لا حكم عام. الربط بالذكاء الاصطناعي: «حافة نطاق الصلاحية» تُدرس نقطةً بنقطة في كل تقريب موضعي.

مثال (49.3-15): تجميع التدرّجات بترتيب حتمي

المعطيات: 8 بطاقات تجمع تدرّجات بمقادير $1/n$ بإشارات متناوبة. الحل: الخطوة 1: ترتيبٌ ثابت حتمي $\Rightarrow$ نتيجة قابلة التكرار (reproducible). الخطوة 2: لكنّها ليست «المجموع الحقيقي» إن كانت المتسلسلة شرطية — بل مجموعُ هذا الترتيب. النتيجة: الحتميّة تعطي التكرار، والتقارب المطلق يعطي الصحّة. الربط بالذكاء الاصطناعي: قابلية التكرار $\neq$ الصحّة العددية، وكلاهما مطلوبٌ separately في أبحاث التعلّم العميق.

أخطاء شائعة

١. **استنتاج التقارب من تناوب الحدود وحده:** لايبنتس يشترط **تناقصاً إلى الصفر**، لا مجرّد تناوب.

٢. **تبديل حدود متسلسلة شرطية:** جائزٌ في المطلقة فقط.

٣. **الخلط بين المطلق والشرطي في تقدير الباقي:** في المطلقة $|R_N| \le \sum_{n>N}|a_n|$، وفي المتناوبة $|R_N| \le a_{N+1}$ فقط.

٤. **تجاهل أن المتوقّع يحتاج تقارباً مطلقاً:** شرطٌ تعريفي لا حسابي.

٥. **الظنّ أن ترتيب الفاصلة العائمة لا يهمّ:** يهمّ، ويزداد كلما كانت المتسلسلة شرطية.

تمهيد قصصي

مهندسٌ يقرّب دالة الخسارة خطّياً حول النقطة الحالية، ثم يتّخذ خطوةً كبيرة «لأن الخطّية دقيقة». فتتباعد الخسارة بدل أن تنقص. سأل: «ألم تكن الخطّية دقيقة؟» فقيل له: **نعم — داخل نصف قطرها فقط.**

كلّ تقريب تايلور هو متسلسلة قوى، ولكل متسلسلة قوى **نصف قطر تقارب** R: داخله التقريب صالح وموحّد، وخارجه لا معنى له، وعلى الحدّ لا حكم عام. وهذا بالضبط هو سببُ وجود «منطقة الثقة» (trust region) في خوارزميات التحسين: لم نكن نُبالغ في الحذر، بل كنّا نحترم R. وفي التعلّم العميق يظهر نصف القطر في كل مكان: في صلاحية متسلسلة نيومان $(I-A)^{-1}=\sum A^k$ (شرطها $\rho(A)<1$)، وفي تقارب تكرار الطاقة، وفي استقرار الشبكات المتكرّرة.

صياغة رسمية

لمتسلسلة القوى $\sum_{n\ge 0} a_n (z-z_0)^n$ نصفُ قطر تقارب R يعطيه صيغة هَدَمار:

$$\frac{1}{R} = \limsup_{n\to\infty} \sqrt[n]{|a_n|}, \qquad R\in[0,\infty] \tag{1.4.49}$$

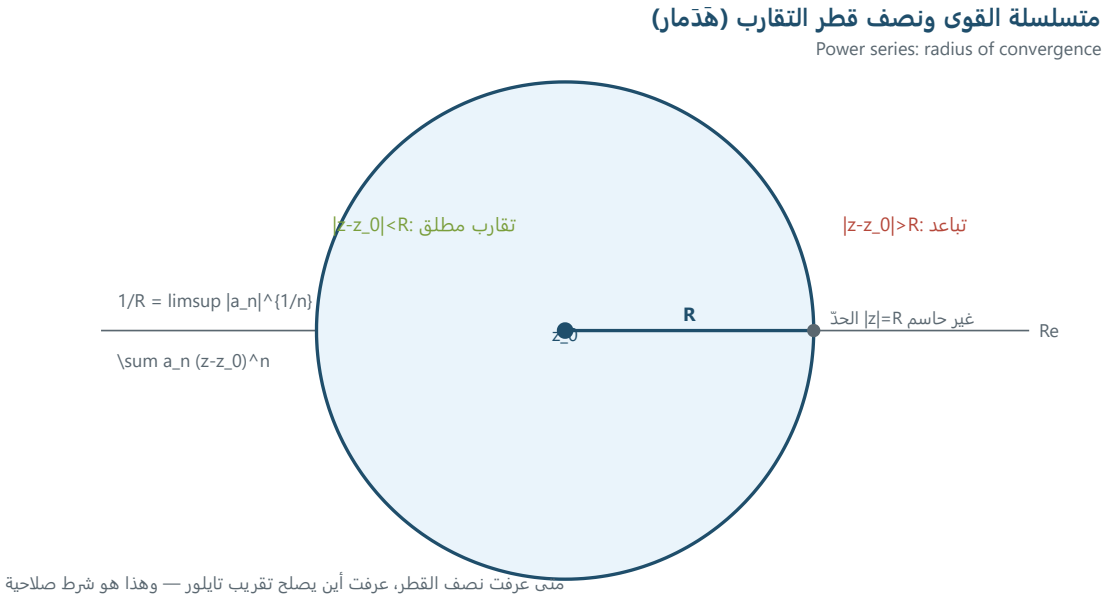
$$|z-z_0|>R \Rightarrow \text{تباعد}, \qquad |z-z_0|<R \Rightarrow \text{تقارب مطلق (وموحّد على كل قرص مغلق أصغر)} \tag{2.4.49}$$

$$\frac{d}{dz}\sum a_n (z-z_0)^n = \sum n a_n (z-z_0)^{n-1}, \qquad \int \sum = \sum \int \quad \text{داخل } R \tag{3.4.49}$$

$$\rho(A)<1 \implies (I-A)^{-1}=\sum_{k=0}^{\infty} A^k, \qquad \Big\| \sum_{k>K} A^k \Big\| \le \frac{\|A\|^{K+1}}{1-\|A\|} \quad \text{(نيومان)} \tag{4.4.49}$$

جدول الرموز

الرمز	المعنى	ملاحظة
z_0	مركز المتسلسلة	نقطة التوسيع
R	نصف قطر التقارب	نطاق الصلاحية
$\limsup$	النهاية العليا	تعمل وإن لم توجد نهاية عادية
$\rho(A)$	نصف القطر الطيفي $\max_i \lvert\lambda_i\rvert$	شرط نيومان
A^k	القوة k للمصفوفة	حدود متسلسلة نيومان
K	حدّ القطع في نيومان	يعطي تقدير الخطأ



شكل ٣.٤٩: *
متسلسلة القوى ونصف قطر التقارب في المستوي المركب

برهان (مخطط)

١. نطبّق معيار الجذر على $|a_n(z-z_0)^n|$: فـ$\sqrt[n]{|a_n|}\,|z-z_0| \to |z-z_0|/R$؛ فهو <1 داخل القرص و>1 خارجه.

٢. الموحّد داخل قرص مغلق أصغر: نأخذ $|z-z_0| \le r < R$ فنحصل $|a_n(z-z_0)^n| \le M_n = |a_n| r^n$ و$\sum M_n < \infty$: معيار M (القسم 5.49).

٣. التفاضل والتكامل حدّاً بحدّ: المتسلسلة المشتقة لها نصف القطر نفسه (لأن $\sqrt[n]{n} \to 1$)، والتقارب الموحّد يبيح تبديل النهاية بالمشتقة/التكامل.

٤. نيومان: من تحليل القيم الذاتية $\rho(A) < 1 \Leftrightarrow \|A^k\| \to 0$ بأُسّ؛ والمجموع الجزئي $(I-A)\sum_{k\le K} A^k = I - A^{K+1} \to I$. ■

شروط الصحّة: صيغة هَدَمار تعمل بـlim sup لا بـlim (وإلا ضاعت حالات التذبذب). ونيومان يشترط $\rho(A) < 1$ لا مجرّد $\|A\| < 1$ (وإن كان الثاني كافياً وأسهل حساباً).

أمثلة محلولة (15)

مثال (4.49-1): المتسلسلة الهندسية

المعطيات: $\sum x^n$، والمطلوب: R والمجموع. الحل: الخطوة 1: $a_n = 1 \Rightarrow \limsup \sqrt[n]{1} = 1 \Rightarrow R = 1$. الخطوة 2: المجموع $= \frac{1}{1-x}$ داخل $|x| < 1$. النتيجة: $R = 1$ والمجموع $\frac{1}{1-x}$. الربط بالذكاء الاصطناعي: الصيغة نفسها لمجموع خصومات المكافآت في التعلّم التعزيزي: $\sum \gamma^k = 1/(1-\gamma)$.

مثال (2-4.49): متسلسلة الأُسّ

المعطيات: $\sum x^n/n!$. الحل: الخطوة 1: $\sqrt[n]{1/n!} \to 0 \Rightarrow R = \infty$. النتيجة: تقارب على كلّ المستوي، والمجموع e^x. الربط بالذكاء الاصطناعي: الأُسّ آمن عدديّاً على كلّ مدى — لذا تُستخدم في softmax وفي دالة الأُسّ المصفوفية.

مثال (3-4.49): لوغاريتم $(1+x)$

المعطيات: $\sum(-1)^{n+1}x^n/n$. الحل: الخطوة 1: $\sqrt[n]{1/n} \to 1 \Rightarrow R = 1$. الخطوة 2: عند $x = 1$ تقارب $(\ln 2)$، وعند $x = -1$ تباعد. النتيجة: $R = 1$ مع سلوكٍ مختلف على طرفي الحدّ. الربط بالذكاء الاصطناعي: تقريب اللوغاريتم في دوالّ الفقد يحتاج $|x| < 1$ — وإلا استخدم صيغةً مستقرة عدديّاً.

مثال (4-4.49): متسلسلة arctan

المعطيات: $\sum(-1)^n x^{2n+1}/(2n+1)$. الحل: الخطوة 1: معاملات $1/(2n+1) \Rightarrow R = 1$. الخطوة 2: عند $x = \pm 1$ تقارب (متناوبة) $\Rightarrow$ المجموع $\pm\pi/4$. النتيجة: $R = 1$ والتقارب على الحدّ متاح. الربط بالذكاء الاصطناعي: مثالٌ على «الحدّ مسموح هنا» — لا تعميم.

مثال (5-4.49): متسلسلة ذات $R = 0$

المعطيات: $\sum n!\, x^n$. الحل: الخطوة 1: $\sqrt[n]{n!} \to \infty \Rightarrow R = 0$. النتيجة: تتقارب فقط عند $x = 0$. الربط بالذكاء الاصطناعي: المتسلسلات المتباعدة في التحليل المُقارب (asymptotic series) من هذا النوع: مفيدة عند حدودٍ قليلة، ولا تتقارب أبداً.

مثال (6-4.49): متسلسلة نيومان للمصفوفات

المعطيات: A مع $\|A\| = 0.8$، والمطلوب: $(I-A)^{-1}$ بمجموع متسلسلة. الحل: الخطوة 1: $\|A\| < 1 \Rightarrow \sum A^k$ تتقارب (بالمعيار عبر النسبة على النواظم). الخطوة 2: خطأ القطع بعد K: $\leq 0.8^{K+1}/0.2$. الخطوة 3: لخطأ $< 10^{-3}$ نحتاج $0.8^{K+1} < 2 \cdot 10^{-4} \Rightarrow K \approx 41$. النتيجة: الحل بـ41 حدّاً بخطأ $< 10^{-3}$. الربط بالذكاء الاصطناعي: حلّ الأنظمة الخطية تكراريّاً (Jacobi/Richardson) وشبكاتُ الحالة (SSM) تعتمد على هذا الشرط الطيفي.

مثال (7-4.49): نصف القطر الطيفي في RNN

المعطيات: مصفوفة الحالة W بـ$\rho(W) = 1.02$. الحل: الخطوة 1: $\rho > 1 \Rightarrow \sum W^k$ تتباعد $\Rightarrow$ الذاكرة تنفجر. الخطوة 2: إعادةُ المعايرة scaled) (init تجعل $\rho \approx 0.99 \Rightarrow$ استقرار. النتيجة: شرط الاستقرار هو $\rho(W) < 1$ بالضبط. الربط بالذكاء الاصطناعي: هذا هو المعيار العملي لتهيئة الأوزان المتكرّرة (spectral/orthogonal init).

مثال (49.4-8): التفاضل حدّاً بحدٍّ

المعطيات: $f(x) = \sum x^n/n^2$. الحل: الخطوة 1: $R = 1$؛ و$f'(x) = \sum x^{n-1}/n$ داخل القرص. النتيجة: التفاضل مباح داخل R. الربط بالذكاء الاصطناعي: التفاضل التلقائي على متسلسلة قوى يعمل داخل نطاق التقارب الموحّد فقط.

مثال (49.4-9): دالة توليد فيبوناتشي

المعطيات: $F_{n+1} = F_n + F_{n-1}$، $F_0 = 0, F_1 = 1$. الحل: الخطوة 1: $G(x) = \sum F_n x^n = \frac{x}{1-x-x^2}$. الخطوة 2: نصف القطر من جذور $1 - x - x^2 = 0$: $R = \frac{\sqrt{5}-1}{2} \approx 0.618$. النتيجة: $R \approx 0.618$ (مقلوب النسبة الذهبية). الربط بالذكاء الاصطناعي: العلاقات التكرارية في النماذج الخطّية تُحل بالطريقة نفسها (تفصيلها القسم 6.49).

مثال (49.4-10): تايلور حول نقطة ونطاق الصلاحية

المعطيات: تقريب $\tanh x \approx x - x^3/3$، والمطلوب: متى يكفي؟ الحل: الخطوة 1: نصف قطر تقارب tanh هو $\pi/2$ (أقربُ قطب في المستوي المركّب). الخطوة 2: عند $|x| < 0.5$ خطأ التقريب $\approx |x|^5/15 < 2 \cdot 10^{-4}$. النتيجة: التقريب ممتاز داخل $|x| \lesssim 0.5$ وسيء قرب $\pi/2$. الربط بالذكاء الاصطناعي: منطقة الثقة في التحسين هي الترجمة الهندسية لنصف قطر التقارب.

مثال (49.4-11): متسلسلة القوى لمقام softmax

المعطيات: $Z = \sum_i e^{w_i}$، والمطلوب: هل $1/Z$ له توسيع؟ الحل: الخطوة 1: نكتب $Z = e^{w_{\max}}\left(1 + \sum_{i \neq \max} e^{w_i - w_{\max}}\right)$. الخطوة 2: التوسيع $\frac{1}{1+u} = \sum (-u)^k$ صالحٌ إذا $|u| < 1$ فقط. النتيجة: التوسيع مشروط بسيطرة الحدّ الأكبر. الربط بالذكاء الاصطناعي: حساب softmax المستقرّ عدديّاً (نقل القيمة القصوى) هو احترامٌ عملي لنصف قطر التقارب.

مثال (49.4-12): نصف قطر من lim sup متذبذب

المعطيات: $a_n = 2^n$ للزوجي و$a_n = 1$ للفردي. الحل: الخطوة 1: $\limsup \sqrt[n]{|a_n|} = 2 \Rightarrow R = 1/2$ (وإن كانت النهاية غير موجودة). النتيجة: $R = 1/2$. الربط بالذكاء الاصطناعي: lim sup لا lim: القاعدة التي تنقذ الحساب في المتسلسلات غير المنتظمة.

مثال (49.4-13): تقدير خطأ قطع متسلسلة قوى

المعطيات: نريد $e^{0.5}$ بخطأ $< 10^{-6}$. الحل: الخطوة 1: الباقي بعد N: $\sum_{n>N} \frac{0.5^n}{n!} \leq \frac{0.5^{N+1}}{(N+1)!} \cdot \frac{1}{1-0.5/(N+2)}$. الخطوة 2: نجد $N = 9$ كافٍ (خطأ $\approx 3 \cdot 10^{-9}$). النتيجة: 10 حدود تكفي. الربط بالذكاء الاصطناعي: ميزانية الحدود تُحسب من الباقي، لا بالتجربة.

مثال (14-4.49): تحليل الأخطاء في تكرار القوة

المعطيات: تكرار القوة لحساب القيمة الذاتية المهيمنة؛ $\lambda_2/\lambda_1 = 0.9$. الحل: الخطوة 1: الخطأ يتناقص كـ 0.9^k $\Rightarrow$ متسلسلة الأخطاء هندسية متقاربة. الخطوة 2: لخطأ 10^{-6} نحتاج $k \approx \frac{\ln 10^{-6}}{\ln 0.9} \approx 131$ تكراراً. النتيجة: 131 تكراراً. الربط بالذكاء الاصطناعي: معدّل التقارب الهندسي هو معيار الجودة في PageRank وتحليل القيم الذاتية.

مثال (15-4.49): متى لا يجوز التفاضل حدّاً بحدٍّ

المعطيات: متسلسلة قوى تقارب على قرص مفتوح فقط. الحل: الخطوة 1: التفاضل مباح داخل القرص المفتوح (تقارب موحّد على الأقراص المغلقة الأصغر). الخطوة 2: لا يجوز على الحدّ دون فحصٍ منفصل. النتيجة: الحكم على الحدّ مستقلّ. الربط بالذكاء الاصطناعي: «صلاحية التقريب حتى نقطة معيّنة» لا تُعمَّم على نقطة أبعد — وهو درس منطقة الثقة نفسه.

أخطاء شائعة

١. **استخدام lim بدل lim sup في هَدَمار:** يفقد نصف القطر في حالات التذبذب.

٢. **تعاميم سلوك الحدّ:** الحدّ يُدرس نقطةً نقطة (3-4.49 مقابل 4-4.49).

٣. **الظنّ أن $\|A\| < 1$ ضروري لنيومان:** يكفي $\rho(A) < 1$؛ و$\|A\| < 1$ شرطٌ كافٍ لا لازم.

٤. **تجاهل نصف القطر في التقريبات الموضعية:** ينتج عنه «خطوة كبيرة فتباعد».

٥. **تقدير الخطأ بالحدّ الأخير فقط:** الباقي قد يكون أكبر بكثير في غير المتناوبة.

تمهيد استفهامي

شبكةٌ تتعلّم دالةً على مجالٍ كامل. بعد كلّ دفعة تدريب يتحسّن الأداء «في كلّ نقطة اختبارناها». فهل يجوز أن نقول: «الشبكة تقترب من الدالة الهدف»؟

الجواب يعتمد على سؤالٍ أدقّ: **هل تقترب بالسرعة نفسها في كل مكان؟** إن كانت كلّ نقطةٍ تتقارب بإيقاعها الخاص، فقد يبقى أسوأ مكان في المجال متخلّفاً إلى الأبد — وهذا هو **التقارب النقطي**، وهو لا يكفي لشيء: لا يحفظ الاستمرارية، ولا يبيح تبديل النهاية بالتكامل أو بالتفاضل. أمّا إن وُجد عددُ خطوات N واحد يصلح للمجال كلّه، فنحن أمام **التقارب الموحّد** — وهو وحده الذي يحفظ ما نحتاجه.

وهذه ليست دقّةً أكاديمية: فمفهوم «التقارب الموحّد» هو نفسه العمود الفقري لنظرية التعلّم الإحصائي (الفصلان 30–34). عندما نقول «يتقارب الخطأ التجريبي إلى الخطأ الحقيقي **موحّداً على عائلة النماذج**»، فنحن نستخدم هذه النظرية بعينها، لا مجرّد استعارة لفظية.

صياغة رسمية

متسلسلة الدوال $\sum u_n(x)$ تقترب من $S(x)$ **نقطيّاً** على D إذا اقتربت في كلّ x، و**موحّداً** إذا:

$$\sup_{x\in D}\left|\sum_{n=1}^{N} u_n(x) - S(x)\right| \xrightarrow[N\to\infty]{} 0 \tag{1.5.49}$$

(2.5.49)

D تقارب موحّد ومطلق على $\sum u_n$ $\implies$ $\sum M_n < \infty$ $\forall x \in D,\ |u_n(x)| \le M_n$ (معيار M)

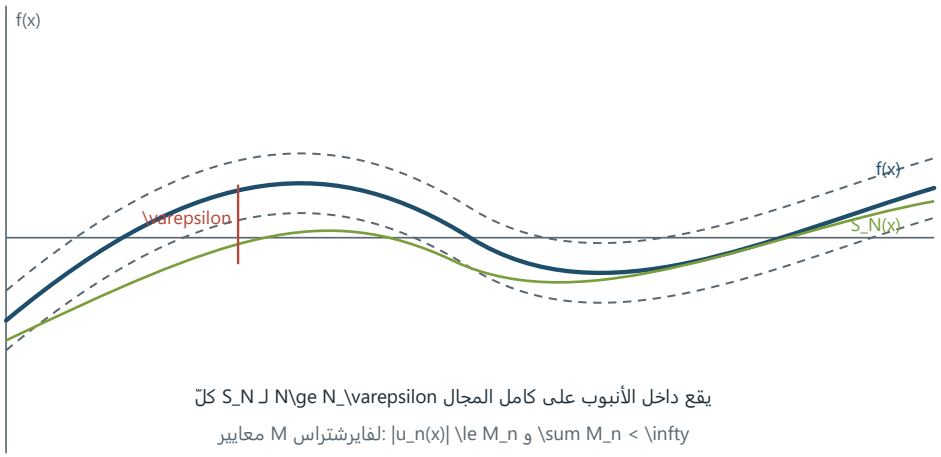
$$\int_D S = \sum_n \int_D u_n \quad \text{متصلة، و } S \implies \text{موحّد + حدود متصلة} \tag{3.5.49}$$

(4.5.49)

متقاربة $\sum u_n(x_0)$ موحّدة و $\sum u'_n$ إذا $\left(\sum u_n\right)' = \sum u'_n$: للتفاضل: يشترط موحّداً للمتسلسلة المشتقة

جدول الرموز

الرمز	المعنى	ملاحظة
$u_n(x)$	حدّ دالّي (دالة لا عدد)	يختلف عن المتسلسلة العددية
D	مجال التقارب	قد يكون مجموعة غير منتهية
$\sup_{x\in D}$	الأسوأ على المجال	هو ما يجعل التقارب موحّداً
M_n	سقف عددي مستقل عن x	قلب معيار M
$S(x)$	دالة النهاية	ميراثُ الموحّد (استمرارية، تكامل)
u'_n	مشتقة الحدّ	شرطٌ إضافي للتفاضل حدّاً بحدّ



شكل ٤٠٤٩: *

التقارب الموحد: أنبوب إبسلون حول دالة النهاية يحصر كل المجاميع الجزئية

برهان (مخطط).

١. **(2.5.49)** الباقي $\left|\sum_{n>N} u_n(x)\right| \le \sum_{n>N} |u_n(x)| \le \sum_{n>N} M_n$، والطرف الأيمن لا يعتمد على x ويزول $\Rightarrow$ تقارب موحّد (وهو مطلق أيضاً).

٢. **(3.5.49 الاستمرارية)** نكتب $|S(x)-S(x_0)| \le |S-S_N|(x)+|S_N(x)-S_N(x_0)|+|S_N-S|(x_0)$: الأول والأخير صغيران بالموحّد (مستقلان عن الموضع)، والأوسط صغير باستمرارية S_N.

٣. **(3.5.49 التكامل)** من الموحّد: $\sup|R_N| \to 0 \Rightarrow \left|\int S - \sum_{n\le N}\int u_n\right| \le \int|R_N| \le |D|\sup|R_N| \to 0$.

٤. **(4.5.49)** نُطبّق نظرية القيمة المتوسطة/التكامل على متسلسلة المشتقات الموحّدة، فتبديل النهاية بالمشتقة مباح. ■

شروط الصحّة: الموحّد لا يكفي للتفاضل (يحتاج موحّداً للمشتقات)؛ والتقارب المطلق لا يستلزم الموحّد في مجالات غير منتهية؛ والمجال D يجب أن يكون مضغوطاً (أو ذا قياس منتهٍ) عند استخدام حجج التكامل أعلاه.

أمثلة محلولة (15)

مثال (1-5.49): x^n على $[0,1)$ — نقطي لا موحّد

المعطيات: $S_N(x)=\sum_{n\le N}$ لا، بل المتتالية $f_N(x)=x^N$ على $[0,1)$. الحل: الخطوة 1: لكلّ $x<1$ ثابت: $x^N \to 0 \Rightarrow$ نقطي. الخطوة 2: $\sup_{x\in[0,1)} x^N = 1$ لكلّ $N \Rightarrow$ لا يزول $\Rightarrow$ غير موحّد. النتيجة: تقارب نقطي فقط. الربط بالذكاء الاصطناعي: «كل نقطة تتحسّن» لا تعني «النموذج يتقارب» — لا ضمان تعميم.

مثال (2-5.49): x^N على $[0,0.5]$ — موحّد

المعطيات: المجال مضغوط أصغر. الحل: الخطوة 1: $\sup_{x\in[0,0.5]} x^N = 0.5^N \to 0 \Rightarrow$ موحّد. النتيجة: تقييد المجال منح الموحّد. الربط بالذكاء الاصطناعي: الضغط/التنظيم (constraining the domain) أداةٌ للحصول على ضمانات تعميم.

مثال (3-5.49): $\sum x^n/n^2$ بمعيار M

المعطيات: $D=[-1,1]$. الحل: الخطوة 1: $|x^n/n^2| \le 1/n^2 = M_n$ و$\sum 1/n^2 < \infty$. الخطوة 2: معيار M $\Rightarrow$ تقارب موحّد ومطلق. النتيجة: النهاية متصلة على $[-1,1]$. الربط بالذكاء الاصطناعي: هذا هو نموذج إثبات أن نهاية سلسلة تقريبات متصلة متصلة.

مثال (4-5.49): التكامل حدّاً بحدٍّ

المعطيات: $S(x)=\sum_{n\ge0}(-1)^n x^n = \frac{1}{1+x}$ على $[0,0.5]$. الحل: الخطوة 1: التقارب موحّد (هندسي بـ$|x|\le 0.5$). الخطوة 2: $\int_0^{0.5} S = \sum(-1)^n \int_0^{0.5} x^n dx = \sum \frac{(-1)^n 0.5^{n+1}}{n+1} = \ln(1.5)$. النتيجة: التكامل حدّاً بحدٍّ صحيح هنا. الربط بالذكاء الاصطناعي: تبديل «توقّع» مع «جمع» في حدود التعميم يحتاج هذا الشرط (أو مبرهنة الهيمنة).

مثال (5-5.49): نهاية دوالّ متصلة غير متصلة

المعطيات: $f_N(x) = x^N$ على $[0,1]$. الحل: الخطوة 1: النهاية $f(x) = 0$ على $[0,1)$ و$f(1) = 1$: متصلة؟ لا — غير متصلة عند 1. الخطوة 2: السبب: التقارب غير موحّد. النتيجة: النقطي لا يحفظ الاستمرارية. الربط بالذكاء الاصطناعي: شبكةٌ تقارب دالةً في كلّ نقطة قد تنتهي إلى حدٍّ غير مستقرّ عدديّاً.

مثال (6-5.49): الموحّد في نظرية التعلّم (GLIVENKO–CANTELLI)

المعطيات: عائلة دوالّ $\mathcal{H}$، والمطلوب: هل $\sup_{h\in\mathcal{H}} |\hat{R}(h) - R(h)| \to 0$؟ الحل: الخطوة 1: هذا تعريفُ التقارب الموحّد على $\mathcal{H}$ (الفصل 31). الخطوة 2: يحتاج سعةً منتهية (بُعد VC أو حدة راديماخر). النتيجة: شرط التعميم = تقارب موحّد على العائلة. الربط بالذكاء الاصطناعي: اللبنة نفسها التي بُني عليها الجزء السادس كله.

مثال (7-5.49): التفاضل حدّاً بحدٍّ يفشل

المعطيات: $S(x) = \sum_{n\geq 1} \frac{\sin(nx)}{n^2}$. الحل: الخطوة 1: $\sum \frac{\sin(nx)}{n^2}$ موحّدة (بمعيار M مع $M_n = 1/n^2$). الخطوة 2: المشتقة $\sum \frac{\cos(nx)}{n}$ **غير** موحّدة التقارب $\Rightarrow$ لا يجوز التفاضل حدّاً بحدٍّ عند كلّ x. النتيجة: S متصلة وليست بالضرورة قابلة للتفاضل. الربط بالذكاء الاصطناعي: متسلسلة فوريه (الفصل 50) تعطي أمثلةً حيّة على هذا الفرق الدقيق.

مثال (8-5.49): معيار M لسلسلة تايلور على قرص

المعطيات: $\sum a_n x^n$ مع $R = 2$ على $|x| \leq 1$. الحل: الخطوة 1: نختار $r = 1.5$ فيوجد C: $|a_n| \leq C/1.5^n \Rightarrow |a_n x^n| \leq C(1/1.5)^n$. الخطوة 2: $\sum C(2/3)^n < \infty \Rightarrow$ موحّد على $|x| \leq 1$. النتيجة: التقارب موحّد على أيّ قرص مغلق داخل R. الربط بالذكاء الاصطناعي: «الهامش داخل نطاق الصلاحية» يعطي استقراراً عدديّاً موحّداً.

مثال (9-5.49): تقارب شبكة على مجموعة مضغوطة

المعطيات: شبكةٌ تقارب f على $[0,1]^d$ المضغوط. الحل: الخطوة 1: على المضغوطات، التقارب الموحّد متاح بمبرهنة التقريب الشامل (الفصل 35). الخطوة 2: وعلى $\mathbb{R}^d$ غير المضغوط لا ضمان موحّد دون تنظيم إضافي. النتيجة: المضغوطية شرطٌ لا غنى عنه. الربط بالذكاء الاصطناعي: سببُ الاهتمام بمجالات البيانات المضغوطة وتنظيم الأوزان.

مثال (49.5-10): خطأُ قطعٍ موحّد في نيومان

المعطيات: $\sum A^k$ مع $\|A\| \le 0.8$. الحل: الخطوة 1: $\|\sum_{k>K} A^k\| \le \sum_{k>K} \|A\|^k = \frac{0.8^{K+1}}{0.2}$ — سقفٌ لا يعتمد على المدخلات. النتيجة: خطأ قطع موحّد على كلّ المدخلات. الربط بالذكاء الاصطناعي: ضمانات الاستقرار في الشبكات المتكرّرة ونماذج الحالة (SSM) من هذا النوع.

مثال (49.5-11): مونتي كارلو موحّد على المعاملات

المعطيات: مقدّر خسارة $\hat{L}(\theta)$ من m عيّنة، والمطلوب: ضمانٌ على $\sup_\theta |\hat{L} - L|$. الحل: الخطوة 1: يحتاج تقارباً موحّداً على فضاء المعاملات (لا نقطيّاً لكلّ θ). الخطوة 2: يتحقّق إذا كان الفضاء مضغوطاً والدالة حُزَميّة (Lipschitz) — ومن ثمّ حدود التغطية. النتيجة: الضمان الموحّد هو ما يجعل ERM متسقاً. الربط بالذكاء الاصطناعي: هذا هو الرابط الدقيق بين التقارب الموحّد و«لماذا يعمل ERM».

مثال (49.5-12): متسلسلة ليست مطلقة لكنها موحّدة

المعطيات: $\sum (-1)^n x^n/n$ على $[0,1]$. الحل: الخطوة 1: التقارب موحّد بمعيار لايبنتس الموحّد (الحدود متناقصة إلى 0 بالتساوي في x). الخطوة 2: وليس مطلقاً عند $x=1$ ($\sum 1/n$ تتباعد). النتيجة: الموحّد أضعف من المطلق-الموحّد وأقوى من النقطي. الربط بالذكاء الاصطناعي: تراتبية المفاهيم تهمّ عند اختيار المعيار المناسب.

مثال (49.5-13): خطأُ تقريب موحّد بطيف متقطّع (Random Fourier Features)

المعطيات: نواة غاوسية تُقرّب بـD ميزة عشوائية. الحل: الخطوة 1: خطأ التقريب ε بمعيار sup على مجال مضغوط يحتاج $D = O(d/\varepsilon^2 \log(1/\varepsilon))$. الخطوة 2: السبب: المطلوب تقاربٌ موحّد، لا تقاربٌ في نقاط العيّنات فقط. النتيجة: حجم الميزات يتضخّم لأن الشرط موحّد. الربط بالذكاء الاصطناعي: يشرح لماذا تحتاج RFF عدداً كبيراً من الميزات لضمانات sup-norm.

مثال (49.5-14): استمرارية النهاية في شبكة متكرّرة

المعطيات: $h_{n+1} = \tanh(Wh_n + Ux)$ والمتسلسلة على الزمن. الحل: الخطوة 1: إذا $\rho(W) < 1$ فالمتسلسلة موحّدة في الزمن $\Rightarrow$ النهاية مستقرة ومتصلة في المدخلات. الخطوة 2: إن لم يكن، فالنهاية قد تكون حسّاسة جدّاً (انفجار/تلاشٍ). النتيجة: الشرط الطيفي يمنح التقارب الموحّد في الزمن. الربط بالذكاء الاصطناعي: التبرير الرياضي لاستقرار التدرّج في المتكرّرات الطويلة.

مثال (49.5-15): تبديل النهاية بالتفاضل في شبكة مكوّنة من لانهاية طبقات

المعطيات: شبكةٌ «عميقة بلا نهاية» (عمق $\to \infty$) تُقرّب دالة. الحل: الخطوة 1: لتبديل النهاية بالمشتقة نشترط

تقارباً موحّداً لمتسلسلة المشتقات. الخطوة 2: وإلا فالنهاية قابلة للتفاضل في نقاط وقد لا تكون المشتقة هي نهاية المشتقات. النتيجة: شرطٌ دقيق يفصل بين «يعمل عملياً» و«مضمون رياضياً». الربط بالذكاء الاصطناعي: حدود NTK (الفصل 40) تتعامل مع هذا النوع من النهايات العريضة.

أخطاء شائعة

١. **الظنّ أن النقطي يكفي للتبديل:** التكامل والتفاضل يحتاجان موحّداً (أو مبرهنة هيمنة).

٢. **تطبيق معيار M بـ M_n تعتمد على x:** يفقد معناه.

٣. **نسيان شرط مضغوطية المجال:** على مجالات غير منتهية يفشل الموحّد غالباً.

٤. **الخلط بين المطلق والموحّد:** كلاهما مطلوب للحصول على الاثنين معاً، وأحدهما لا يستلزم الآخر.

٥. **افتراض التفاضل حدّاً بحدٍّ من موحّد المتسلسلة الأصلية:** المطلوب موحّد المشتقات.

تمهيد قصصي

علاقةٌ تكرارية بسيطة تحكم متتالية: $v_n = \beta v_{n-1} + (1-\beta) g_n$. هل تعرف أحداً؟ إنها — بحروفٍ أخرى — **زخم آدم**: متوسطٌ متحرّك أُسّي لا ينسى الماضي، بل يخفت صوته تدريجياً.

السؤال العملي عن هذه المتتالية ليس «ما هو v_{100}؟» بل: **كم من الماضي يعيش في v_n؟ وهل ينفجر؟ وهل يمكن عكسه؟** الحساب المباشر يُجيب عن الأولى فقط. لكن هناك حيلةً قديمة تعود إلى أويلر ولابلاس: **اكتب المتتالية دالةً.** خُذ المتتالية كلّها واجعلها معاملاتِ دالةٍ واحدة $A(z) = \sum a_n z^n$، فتنقلب العلاقة التكرارية إلى **معادلة جبريّة** تُحلّ بقسمة كثيرات حدود، ويتحوّل السؤال عن النمو والانفجار إلى سؤال عن **مواقع الأقطاب**: هل هي داخل دائرة الوحدة أم خارجها؟

هذه هي الدالة المولّدة (generating function) في صورتها العادية، وهي نفسها **تحويل Z** في معالجة الإشارة — أحد أعمدة الفصول القادمة. فالفرق بينهما ليس رياضياً بل اصطلاحي: z^n مقابل z^{-n}، وتسمية الحروف.

صياغة رسمية

$$A(z) = \sum_{n \ge 0} a_n z^n, \qquad a_n = [z^n] A(z) \qquad \text{(دالة مولّدة عادية)} \tag{1.6.49}$$

$$a_n = \sum_{k=1}^{K} c_k a_{n-k} \implies A(z) = \frac{P(z)}{1 - \sum_k c_k z^k} \qquad \text{تكرارية خطّية ثابتة المعاملات:} \tag{2.6.49}$$

$$X(z) = \sum_{n \ge 0} x_n z^{-n}, \qquad \mathcal{Z}\{x_{n-1}\} = z^{-1} X(z) \qquad \text{(تحويل Z وخاصية الإزاحة)} \tag{3.6.49}$$

$$H(z) = \frac{Y(z)}{X(z)} \text{ دالة التحويل} \qquad \mathcal{Z}\{(h * x)_n\} = H(z)\,X(z), \quad \text{(الالتفاف)} \tag{4.6.49}$$

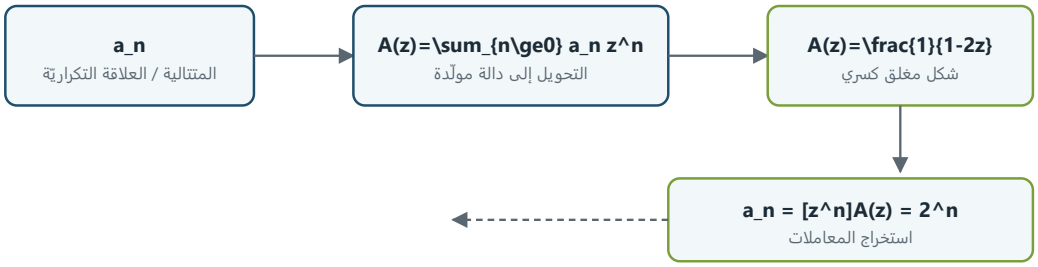
$$\text{مستقرٌّ (BIBO) } H(z) \text{ النظام} \iff |z| < 1 \text{ كلّ أقطابه داخل دائرة الوحدة} \tag{5.6.49}$$ (الاستقرار)

جدول الرموز

الرمز	المعنى	ملاحظة
$A(z)$	الدالة المولّدة (OGF)	تجمع المتتالية كلّها
$[z^n]A$	معامل z^n	استخراج الحدّ n
c_k	معاملات التكرارية	تظهر في مقام الدالة المولّدة
$X(z)$	تحويل Z للإشارة x_n	z^n بدل z^{-n}
$H(z)$	دالة التحويل (transfer)	الجواب النبضيّ في مجال التردّد
$h * x$	الالتفاف (convolution)	ترشيح الإشارة
z^{-1}	عنصر تأخير بوحدة زمن	element delay

من المتتالية إلى الدالة المولّدة وإلى الشكل المغلق

Generating function pipeline



العلاقة التكراريّة تصير معادلة جبريّة: $2a_{n-1} \Rightarrow A(z) = a_0 + 2zA(z)$

النظير الحديث: تحويل Z في معالجة الإشارة، ودوال التوليد في عدّ نماذج الشبكات.

شكل ٥.٤٩: *
من العلاقة التكرارية إلى الدالة المولدة إلى الشكل المغلق ثم استخراج المعاملات

برهان (مخطط)

١. **(2.6.49)** نضرب العلاقة التكرارية بـz^n ونجمع على $n \geq K$: فتظهر $A(z)$ في الطرفين مع إزاحات $z^k A(z)$، ونحلّ جبريّاً.

٢. **(3.6.49)** من $\sum x_{n-1} z^{-n} = z^{-1} \sum x_m z^{-m}$: الإزاحة زمنيّاً = ضربٌ في z^{-1} في مجال Z.

٣. **(4.6.49)** نحسب: $\mathcal{Z}\{\sum_k h_k x_{n-k}\} = \sum_k h_k z^{-k} X(z) = H(z)X(z)$: الالتفاف ضرب.

٤. **(5.6.49)** الشكل المغلق بالمقسوم عليه يعطي توسيعاً $\sum c_j \lambda_j^n$ حيث λ_j جذور المقام؛ فالاستقرار $\Leftrightarrow |\lambda_j| < 1$ كلها. ■

شروط الصحّة: التوسيع صالح داخل نصف قطر التقارب (القسم 4.49)؛ ودائرة الوحدة في (5.6.49) تفترض النظام السببيّ (causal) — وللأنظمة غير السببية يتغيّر شرط منطقة التقارب (ROC).

أمثلة محلولة (15)

مثال (1-6.49): فيبوناتشي — من التكرارية إلى بينيه

المعطيات: $F_{n+1} = F_n + F_{n-1}$، $F_0 = 0, F_1 = 1$. الحل: الخطوة 1: $G(z) = \sum F_n z^n \Rightarrow G = z + zG + z^2G$. الخطوة 2: التجزئة الجزئية بجنوري $1 - z - z^2 = 0$: $G(z) = \frac{z}{1-z-z^2}$. الخطوة 3: $\varphi = \frac{1+\sqrt{5}}{2}$، $\psi = \frac{1-\sqrt{5}}{2}$. النتيجة: شكلٌ مغلق من تكرارية (صيغة بينيه). $F_n = \frac{\varphi^n - \psi^n}{\sqrt{5}}$. الربط بالذكاء الاصطناعي: النموذج النموذجي لكيفية تحويل التكرارية إلى أُسّيّات (اقتصاديات الذاكرة في RNN).

مثال (2-6.49): التضاعف البسيط

المعطيات: $a_n = 2a_{n-1}$، $a_0 = 1$. الحل: الخطوة 1: $A(z) = 1 + 2zA(z) \Rightarrow A(z) = \frac{1}{1-2z}$. الخطوة 2: $a_n = 2^n$، ونصف القطر $R = 1/2$. النتيجة: القطب عند $z = 1/2$ يحدّد معدّل النمو. الربط بالذكاء الاصطناعي: القطب خارج/داخل دائرة الوحدة يفصل الانفجار عن التلاشي.

مثال (3-6.49): جذر مكرّر

المعطيات: $a_n = 2a_{n-1} - a_{n-2}$، $a_0 = 0, a_1 = 1$. الحل: الخطوة 1: $A(z) = \frac{z}{(1-z)^2}$ (جذر مكرّر عند 1). الخطوة 2: المعاملات $a_n = n$ (نمو خطّي من جذر مكرّر). النتيجة: الجذور المكرّرة تعطي حدوداً من الشكل $n^m\lambda^n$. الربط بالذكاء الاصطناعي: الجذور المكرّرة في مصفوفات الحالة $\Rightarrow$ نمو متعدد الحدود (أبطأ من الأُسّي لكنه غير منتهٍ).

مثال (4-6.49): تكرارية غير متجانسة

المعطيات: $a_n = a_{n-1} + n$، $a_0 = 0$. الحل: الخطوة 1: $A(z) = zA(z) + \sum nz^n = zA(z) + \frac{z}{(1-z)^2}$. الخطوة 2: $A(z) = \frac{z}{(1-z)^3} \Rightarrow a_n = \frac{n(n+1)}{2}$. النتيجة: التراكم التربيعي. الربط بالذكاء الاصطناعي: جمع التدرّجات المتراكمة (cumulative sum) في محسّنات الزخم من هذا النوع.

مثال (5-6.49): تحويل Z للخطوة الواحدة

المعطيات: $x_n = 1$ لـ $n \geq 0$. الحل: الخطوة 1: $X(z) = \sum z^{-n} = \frac{1}{1-z^{-1}} = \frac{z}{z-1}$، صالح لـ $|z| > 1$. النتيجة: قطب عند $z = 1$ — على حدّ الاستقرار تماماً. الربط بالذكاء الاصطناعي: النظام ذو القطب على دائرة الوحدة «مستقرّ هامشيّاً»: لا ينفجر ولا ينسى.

مثال (6-6.49): التضاؤل الأُسّي واستقرار المرشّح

المعطيات: $h_n = 0.9^n$ (استجابة نبضية). الحل: الخطوة 1: $H(z) = \frac{1}{1-0.9z^{-1}}$، قطب عند 0.9 داخل الوحدة $\Rightarrow$ مستقر. الخطوة 2: الاستجابة تموت أُسّياً. النتيجة: مرشّح IIR مستقر. الربط بالذكاء الاصطناعي: الزخم في SGD مرشّح IIR بقطب μ: استقرارُه شرطُه $\mu < 1$.

مثال (7-6.49): الالتفاف ضرب

المعطيات: مرشّح $h = (1, 2, 1)$ وإشارة x. الحل: الخطوة 1: $H(z) = 1 + 2z^{-1} + z^{-2} = (1 + z^{-1})^2$. الخطوة 2: الخرج $Y(z) = H(z)X(z)$ بدل حساب الالتفاف المباشر. النتيجة: ترشيح = ضرب كثير حدود.

الربط بالذكاء الاصطناعي: الالتفاف في الشبكات الالتفافية (الفصل 37) يمكن حسابه في مجال التردّد — أسرع للنواة الكبيرة.

مثال (8-6.49): دالة التحويل لطبقة متكرّرة

المعطيات: $h_n = Wh_{n-1} + Ux_n$. الحل: الخطوة 1: $H(z) = (I - Wz^{-1})^{-1}UX(z)$. الخطوة 2: الأقطاب = قيم W الذاتية؛ الاستقرار $\Leftrightarrow \rho(W) < 1$. النتيجة: تحليلُ RNN في مجال Z. الربط بالذكاء الاصطناعي: أقطاب مصفوفة الحالة تحدّد طول الذاكرة الفعّال في الشبكات المتكرّرة ونماذج الحالة (SSM/S4).

مثال (9-6.49): زخم SGD مرشّحاً

المعطيات: $v_n = \mu v_{n-1} + g_n$، $\mu = 0.9$. الحل: الخطوة 1: $V(z) = \frac{G(z)}{1-\mu z^{-1}} \Rightarrow$ الاستجابة النبضية μ^n. الخطوة 2: المجموع الكلّي لاستجابة نبضة واحدة $= \sum \mu^n = \frac{1}{1-\mu} = 10$. النتيجة: الزخم يضخّم التدرّج الثابت 10 أضعاف. الربط بالذكاء الاصطناعي: تفسيرُ سبب الحاجة لتصحيح الانحياز (bias correction) في بداية تدريب Adam.

مثال (10-6.49): نافذة الزمن الفعّالة لآدم

المعطيات: $v_n = \beta v_{n-1} + (1-\beta)g_n^2$، $\beta = 0.999$. الحل: الخطوة 1: الاستجابة النبضية $(1-\beta)\beta^n$؛ ومجموعها 1 (مُعايَر). الخطوة 2: الزمن المميّز $\tau = \frac{1}{1-\beta} = 1000$ خطوة. النتيجة: آدم «يتذكّر» ألف خطوة تقريباً. الربط بالذكاء الاصطناعي: يفسّر سلوك Adam في المهام ذات التدرّجات المتفرّقة (sparse gradients).

مثال (11-6.49): دالة مولّدة احتمالية

المعطيات: $G(s) = \mathbb{E}[s^X] = \sum p_n s^n$. الحل: الخطوة 1: $G'(1) = \mathbb{E}[X]$، و$= G''(1) + G'(1) - G'(1)^2$ $\mathrm{Var}(X)$. الخطوة 2: للبواسون $G(s) = e^{\lambda(s-1)} \Rightarrow$ متوسط λ وتباين λ. النتيجة: العزوم من مشتقات الدالة المولّدة عند 1. الربط بالذكاء الاصطناعي: الدالة المولّدة للعزوم (MGF) أداة معيار تشيرنوف (الفصل 17) — الفكرة ذاتها.

مثال (49.6-12): عدّ البنى بالدوال المولّدة

المعطيات: كم سلسلة ثنائية بطول n بلا صفرين متتاليين؟ الحل: الخطوة 1: التكرارية $a_n = a_{n-1} + a_{n-2}$ (فيبوناتشي) $\Rightarrow A(z) = \frac{1+z}{1-z-z^2}$. الخطوة 2: $a_n = F_{n+2} \Rightarrow$ نموٌّ أُسّي بمعدّل φ^n. النتيجة: عددٌ ينمو بالنسبة الذهبية. الربط بالذكاء الاصطناعي: عدّ البنى (عدد شبكات/أشجار/مسارات) أداةٌ أساسية في تحليل سعة العائلة (الفصل 31).

مثال (49.6-13): عكس تحويل Z (استخراج المعاملات)

المعطيات: $H(z) = \frac{1}{1-0.5z^{-1}}$، والمطلوب: h_n. الحل: الخطوة 1: التوسيع الهندسي: $H(z) = \sum (0.5)^n z^{-n}$. الخطوة 2: إذن $h_n = 0.5^n$. النتيجة: الاستجابة النبضية تضاؤل أُسّي. الربط بالذكاء الاصطناعي: استخراج المعاملات هو «فكّ الترميز»: من التحويل إلى الإشارة.

مثال (49.6-14): مرشّح FIR كنواة التفاف

المعطيات: نواة التفاف $k = (k_0, \dots, k_{L-1})$. الحل: الخطوة 1: $K(z) = \sum k_\ell z^{-\ell}$: كثير حدود بلا أقطاب (إلا عند 0). الخطوة 2: لا يوجد تلقيم راجع $\Rightarrow$ مستقرّ دائماً. النتيجة: FIR مستقرّ بطبيعته، بخلاف IIR. الربط بالذكاء الاصطناعي: يفسّر أمان التفاف CNN مقابل حساسية RNN للتهيئة.

مثال (49.6-15): منطقة التقارب ROC

المعطيات: $X(z) = \frac{1}{1-2z^{-1}}$، والمطلوب: هل الإشارة متنامية أم متضائلة؟ الحل: الخطوة 1: التوسيع بـz^{-1} يعطي 2^n إذا افترضنا $|z| > 2$ (إشارة يمينية متضاعفة). الخطوة 2: والتوسيع ذاته بـz يعطي إشارة يسارية متضائلة إذا $|z| < 2$. النتيجة: الدالة وحدها لا تكفي — لا بدّ من منطقة التقارب. الربط بالذكاء الاصطناعي: درسٌ عام: التحويل لا يُعكس بلا معلومة إضافية (السببيّة هنا نظيرُها شروطٌ هندسية elsewhere).

أخطاء شائعة

١. **تجاهل منطقة التقارب:** الدالة المولّدة بلا ROC لا تعيّن المتتالية (49.6-15).

٢. **الظنّ أن كل تكرارية تُحل بجذور بسيطة:** الجذور المكرّرة تعطي حدوداً $n^m \lambda^n$.

٣. **الخلط بين z^n وz^{-n}:** اصطلاح الدالة المولّدة معاكس لتحويل Z؛ التحويل بينهما $z \leftrightarrow z^{-1}$.

٤. **اعتبار الاستقرار مساوياً لـ$\|W\| < 1$:** الشرط الدقيق $\rho(W) < 1$.

٥. **نسيان معايرة المتوسط المتحرّك:** بدون $(1-\beta)$ لا يكون المجموع $1 \Rightarrow$ انحياز في بداية التدريب.

تمهيد قصصي

منحنى خسارة التدريب يهتزّ: خطوةٌ ينخفض، وخطوةٌ يرتفع، ولا يقترب من حدٍّ ثابت بالمعنى التقليدي. مهندسٌ يقول: «إذن لم يتقارب التدريب». وآخر أذكى يقول: «**المتوسط المتحرّك يقترب — وهذا يكفيني**».

هذا الموقف الثاني هو جوهر **تجميع المتسلسلات** (summability): أن نُبدّل مفهوم «المجموع» بمفهومٍ أوسع يروّض التذبذب، على أن يتفق مع المجموع العادي كلّما وُجد. فسيزارو يأخذ متوسط المجاميع الجزئية، وأبيل يُدخل عاملاً مثبّطاً r^n ثم يقترب به من 1. والجميل أن الاثنين **يتفقان** حيث يوجد مجموعٌ تقليدي، ويعطيان قيمةً معقولة حيث لا يوجد — مثل $1-1+1-1+\cdots$ الذي يصير $\frac{1}{2}$.

وفي التعلّم العميق، متوسطات التدرّج (EMA) و«حساء النماذج» (model soup) ليست إلا تطبيقاً لهذه الفكرة: حين تعجز النهايةُ النقطية، **استبدلها بنهاية وسطى**.

صياغة رسمية

$$\sum a_n = S \text{ بمعنى سيزارو} \quad \Longleftarrow \quad \sigma_N = \frac{1}{N}\sum_{k=1}^{N} S_k \xrightarrow{N\to\infty} S \qquad \text{(سيزارو)} \tag{1.7.49}$$

$$\sum a_n \overset{A}{=} \lim_{r\to 1^-} A(r) \qquad A(r)=\sum_{n\ge 0} a_n r^n \ (0\le r<1), \qquad \text{(أبيل)} \tag{2.7.49}$$

$$\sum a_n = S \text{ بالمفهوم التقليدي} \ \Longrightarrow \ \sum a_n \overset{A}{=} S \qquad \text{(نظرية أبيل للحدّ)} \tag{3.7.49}$$

$$\sum_{n=p}^{q} u_n v_n = U_q v_q - U_{p-1} v_p + \sum_{n=p}^{q-1} U_n (v_n - v_{n+1}), \quad U_n=\sum_{k\le n} u_k \qquad \text{(تجزيء أبيل)} \tag{4.7.49}$$

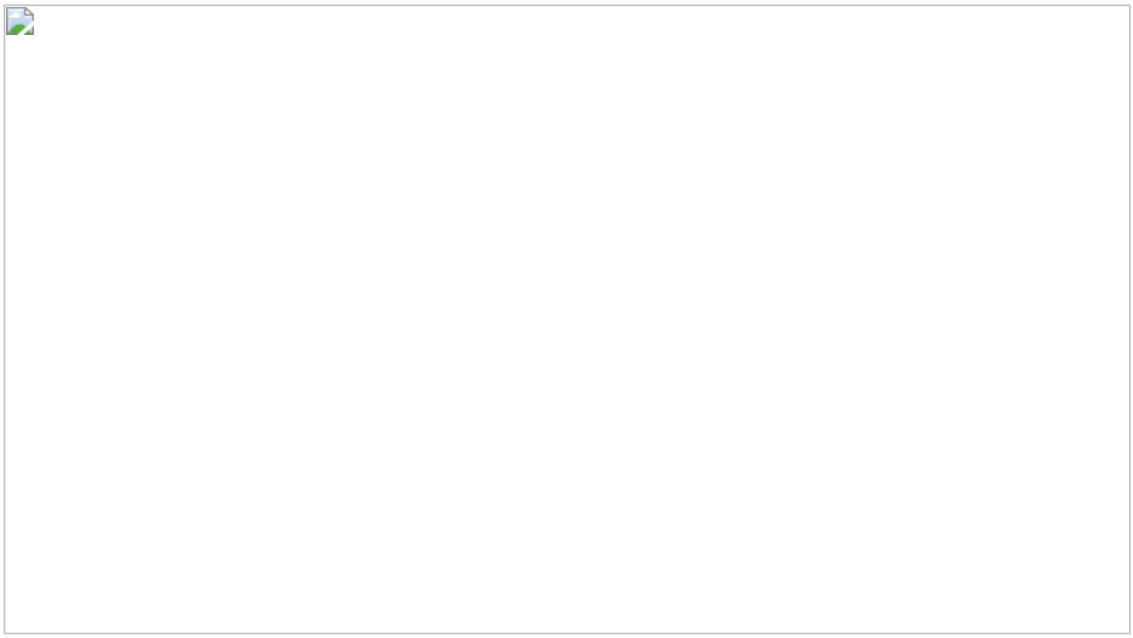
جدول الرموز

الرمز	المعنى	ملاحظة
S_k	المجموع الجزئيّ k	مادة التجميع
σ_N	متوسط سيزارو للمجاميع	يروّض التذبذب
$A(r)$	متسلسلة القوى المثبّطة	أداة أبيل
r	عامل التثبيط $r\to 1^-$	أشبهُ بمعدّل النسيان
U_n	مجاميع جزئية لـu	تظهر في تجزيء أبيل
$\overset{A}{=}$	مساواة بمعنى أبيل	أوسع من التقليدية

برهان (مخطط)

١. **(3.7.49)** إذا $S_N \to S$ فـ$\sigma_N = \frac{1}{N}\sum S_k \to S$ (نظرية سيزارو للمشتقات: متوسط متتالية متقاربة يقترب إلى الحدّ نفسه). ولأبيل: $A(r)=(1-r)\sum S_n r^n$ وهي متوسط مرجّح يزن الذيل بوزن يتلاشى $\Rightarrow (1-r)\sum S_n r^n \to S$ لأن $\sum (1-r)r^n = 1$.

٢. **(4.7.49)** نعيد ترتيب المجموع المزدوج: $\sum u_n v_n = \sum (U_n - U_{n-1})v_n$ ونبدّل الفهارس فتظهر فروق v.



شكل ٦.٤٩: *
ترويض متسلسلة متذبذبة بمتوسطات سيزارو وتجميع أبيل

٣. **(اتفاق الطريقتين)** إن وُجد المجموع التقليدي فكلّ طريقة تجميع «منتظمة» (regular) تعطيه. ■

شروط الصحّة: التجميع لا يخترع قيمةً لكلّ متسلسلة؛ فـ$\sum n$ لا يُجمَع بسيزارو وإن أُعطي قيمةً بتجميعٍ آخر أو بتحليلٍ مُقارب. وقيم التجميع ليست «مجاميع» بالمعنى العادي — تُستخدم حيث يبرّرها السياق الفيزيائي/الهندسي.

أمثلة محلولة (15)

مثال (1-7.49): $1-1+1-1+\cdots$ بسيزارو

المعطيات: $a_n=(-1)^n$، $S_k\in\{1,0\}$. الحل: الخطوة 1: $\frac{1}{2}\to\frac{1}{N}\sum S_k=\sigma_N$. الخطوة 2: المتسلسلة لا تتقارب تقليديّاً (الحدود لا تزول). النتيجة: المجموع بمعنى سيزارو $=1/2$. الربط بالذكاء الاصطناعي: المتوسط المتحرّك يعطي قيمةً مستقرة حيث لا تعطي القيم الآنيّة شيئاً.

مثال (2-7.49): المتسلسلة ذاتها بأبيل

المعطيات: $A(r)=\sum(-1)^n r^n=\frac{1}{1+r}$. الحل: الخطوة 1: $\frac{1}{2}=\lim_{r\to1^-}\frac{1}{1+r}$. النتيجة: أبيل يعطي $1/2$ كسيزارو. الربط بالذكاء الاصطناعي: التثبيط التدريجي (annealing) يعادل نهج أبيل: ابدأ بمثبّط ثم ارفعه تدريجيّاً.

مثال (49.7-3): اتفاق الطرق عند وجود المجموع

المعطيات: $\sum (1/2)^n = 1$. الحل: الخطوة 1: سيزارو: $\sigma_N \to 1$ (نظرية سيزارو). الخطوة 2: أبيل: $A(r) = \frac{1}{1-r/2} \to 2$؟ لا — نضبط الفهارس من $n \geq 1$: $A(r) = \frac{r/2}{1-r/2} \to 1$ ✓. النتيجة: كلّ الطرق تعطي 1. الربط بالذكاء الاصطناعي: الانتظام (regularity) شرطُ أيّ طريقة تجميع: ألا تغيّر ما هو معلوم.

مثال (49.7-4): متوسط متحرّك أُسّي (EMA)

المعطيات: $m_n = \beta m_{n-1} + (1-\beta)x_n$. الحل: الخطوة 1: m_n متوسط مرجّح بوزن $(1-\beta)\beta^k$ — نظيرُ تجميع أبيل بـ $r = \beta$. الخطوة 2: كلما زاد β صار المتوسط أثقل وأهدأ. النتيجة: EMA تجميعٌ على طريقة أبيل. الربط بالذكاء الاصطناعي: هذا هو التفسير الدقيق لـ«لماذا يهدّئ EMA منحنى التدريب».

مثال (49.7-5): تصحيح انحياز آدم

المعطيات: $v_n = \beta v_{n-1} + (1-\beta)g_n^2$، $v_0 = 0$. الحل: الخطوة 1: في البداية v_n منحاز للصفر لأن المجموع الكلّي للأوزان $1 - \beta^n < 1$. الخطوة 2: التصحيح $\hat{v}_n = v_n/(1-\beta^n)$ يعيد الأوزان إلى المجموع 1. النتيجة: تصحيح الانحياز = تطبيع طريقة التجميع. الربط بالذكاء الاصطناعي: مثالٌ كلاسيكي على أن التجميع غير المُعايَر يُدخل انحيازاً منهجيّاً.

مثال (49.7-6): تجزيء أبيل لإثبات ديريكلِه

المعطيات: $\sum b_n c_n$ بمجاميع b محدودة و$c_n \searrow 0$. الحل: الخطوة 1: بالتجزيء: $|\sum_p^q b_n c_n| \leq 2Mc_p + M(c_p - c_{q+1}) \to 0$. النتيجة: المتسلسلة تتقارب (لا يشترط تقارباً مطلقاً). الربط بالذكاء الاصطناعي: الأداة التي تُثبت تقارب متسلسلات فوريه عند نقاط الاستمرار.

مثال (49.7-7): متسلسلة متذبذبة في تقدير الخسارة

المعطيات: خسارةٌ تتذبذب بين 0.2 و0.3. الحل: الخطوة 1: النهاية النقطية غير موجودة؛ متوسط سيزارو $\to 0.25$. الخطوة 2: قرار «التوقّف» يُبنى على المتوسط لا على القيمة الآنيّة. النتيجة: التجميع يعطي معيار توقّف مستقرّاً. الربط بالذكاء الاصطناعي: معايير التوقّف المبكر (early stopping) تعمل على متوسط متحرّك للسبب نفسه.

مثال (49.7-8): سيزارو لا يجمّع كل شيء

المعطيات: $a_n = n$. الحل: الخطوة 1: $S_k \sim k^2/2 \Rightarrow \sigma_N \sim N^2/6 \to \infty$. النتيجة: لا تجميع بسيزارو. الربط بالذكاء الاصطناعي: المتوسط لا ينقذ انفجاراً حقيقيّاً — بل تذبذباً فقط.

مثال (49.7-9): نافذةُ تجميع واستجابة نبضية

المعطيات: تجميع بمتوسط متحرّك طوله L. الحل: الخطوة 1: الاستجابة النبضية ثابتة $1/L$ على L عيّنة ثم صفر. الخطوة 2: في مجال التردّد: مرشّح تمرير منخفض (sinc) — تفصيله الفصل 51. النتيجة: التجميع ترشيحٌ منخفض التمرير. الربط بالذكاء الاصطناعي: متوسط التدرّجات يزيل «الضجيج عالي التردّد» — حرفيّاً بالمعنى الطيفي.

مثال (49.7-10): نظرية أبيل وحساب المجاميع

المعطيات: نريد $\sum_{n\ge 1}\frac{(-1)^{n+1}}{n}=\ln 2$. الحل: الخطوة 1: $A(r)=\sum(-1)^{n+1}r^n/n=\ln(1+r)$. الخطوة 2: $\lim_{r\to 1^-}\ln(1+r)=\ln 2$ ✓. النتيجة: أبيل يؤكّد القيمة المعروفة. الربط بالذكاء الاصطناعي: التثبيط يجعل المتسلسلة مطلقة التقارب مؤقّتاً — ثم يُرفع بحذر.

مثال (49.7-11): التجميع والتعميم (model soup)

المعطيات: ثلاثة نماذج بخسائر $0.21, 0.24, 0.22$ وأوزان مختلفة. الحل: الخطوة 1: متوسط الأوزان يعطي نموذجاً بخسارةٍ أفضل من المتوسط (غالباً). الخطوة 2: التبرير: التجميع يخفض تباين المسار ويبقي التحيز. النتيجة: «حساء النماذج» تطبيقٌ لتقليل التباين بالتجميع. الربط بالذكاء الاصطناعي: وزنه النظري في الفصل 30 (التحيز–التباين) و34 (الانحياز الضمني).

مثال (49.7-12): تجميع سيزارو لمتسلسلة فوريه

المعطيات: متسلسلة فوريه لدالة متصلة لا تتقارب نقطيّاً في نقطة. الحل: الخطوة 1: مجاميع فيير (متوسطات سيزارو للمجاميع الجزئية) تتقارب موحّداً إلى الدالة. الخطوة 2: نواة فيير موجبة — بخلاف نواة ديريكلِه المتذبذبة. النتيجة: التجميع يصلح ما أفسده التذبذب. الربط بالذكاء الاصطناعي: مقدّمة مباشرة لظاهرة غيبس في الفصل 50.

مثال (49.7-13): تثبيطُ التعلّم (learning-rate warmup)

المعطيات: بدء التدريب بمعدّل صغير ثم رفعه. الحل: الخطوة 1: أشبهُ بأبيل: ابدأ بـr صغير (حركة مقيّدة) ثم ارفعه. الخطوة 2: يمنع الانفجار في المرحلة غير المستقرّة. النتيجة: استقرار المرحلة الأولى. الربط بالذكاء الاصطناعي: الإحماء التدريجي من الوسائل العملية لترويض التذبذب المبكر.

مثال (49.7-14): متى يُخفي التجميع مشكلة حقيقية

المعطيات: خسارةٌ تبدو مستقرّة بالمتوسط لكنها ترتفع تدريجيّاً. الحل: الخطوة 1: المتوسط المتحرّك يتأخّر (lag)؛ الارتفاع البطيء قد لا يظهر. الخطوة 2: راقب المتوسط والقيمة الآنيّة معاً. النتيجة: التجميع أداةٌ لا بديل عن

التشخيص. الربط بالذكاء الاصطناعي: تحذيرٌ منهجي: لا تُخفِ الانحرافات المنهجية خلف متوسط ناعم.

مثال (49.7-15): تجميع تدرّجات موزّعة

المعطيات: W عامل يجمع تدرّجاته بمتوسط متحرّك. الحل: الخطوة 1: المتوسط يقلّل تباين التقدير بنسبة W (إذا كان الضجيج مستقلاً). الخطوة 2: ويبقي التحيز كما هو — فلا يحلّ مشكلة التحيّز المنهجي. النتيجة: تجميع $\longleftarrow$ تقليل تباين لا تقليل تحيّز. الربط بالذكاء الاصطناعي: الحساب الموزّع يستفيد من التجميع للسبب الإحصائي نفسه.

أخطاء شائعة

١. **اعتبار قيمة التجميع «مجموعاً» بمعنى الكلمة:** هي قيمةُ طريقة تجميع، تحتاج تبريراً من السياق.

٢. **الظنّ أن التجميع يحلّ الانفجار:** لا يجمّع سيزارو متسلسلةً متباعدة إلى ∞ (49.7-8).

٣. **تجاهل انحياز المتوسط غير المُعايَر:** كما في بداية آدم (49.7-5).

٤. **استنتاج الاستقرار من منحنى ناعم:** المتوسط يؤجّل ظهور الاتجاه (49.7-14).

٥. **تطبيق سيزارو على متسلسلة متقاربة أصلاً بلا داع:** لا يضيف، لكنه لا يضرّ (الانتظام).

تمهيد قصصي

لماذا نبدو أذكياء حين نكتب الصورة بلغة التردّدات؟ لأن **العموديّة تحفظ الطاقة**: إذا كان لديك نظامٌ من الاتجاهات المتعامدة، فإن تحلّل الإشارة إليها يوزّع طاقتها على مكوّناتها توزيعاً لا يضيع منه شيء. فالمجموع يكون مساوياً للكلّ — لا أكبر ولا أصغر.

تخيّل أنك تضغط صورة: تحوّلها، وتحذف المكوّنات الصغيرة، وتعيد تركيبها. كم فقدت من الطاقة؟ الجواب الدقيق تعطيه **متفاوتة بيسل** (لا تفقد أكثر من مجموع ما حذفت) و**مساواة بارسيفال** (إذا كان النظام كاملاً، فالطاقة محفوظة بالضبط). وهذا هو المبدأ الذي يقوم عليه ضغط JPEG وMP3، وتقطير المعاملات في الشبكات، وحتى تفسير «لماذا تعمل المويجات».

وهو أيضاً الجسر الطبيعي إلى الفصل القادم: فمتسلسلة فوريه ليست إلا تطبيقاً لهذه النظرية على النظام المتعامد $\{\sin nx, \cos nx\}$.

صياغة رسمية

ليكن $\{e_k\}$ نظاماً عمودياً معيارياً في فضاء هيلبرت $\mathcal{H}$ بجداء داخلي $\langle \cdot, \cdot \rangle$. فإنّ:

$$\sum_{k} \left|\langle f, e_k\rangle\right|^2 \le \|f\|^2 \qquad \text{(بيسل)} \tag{1.8.49}$$

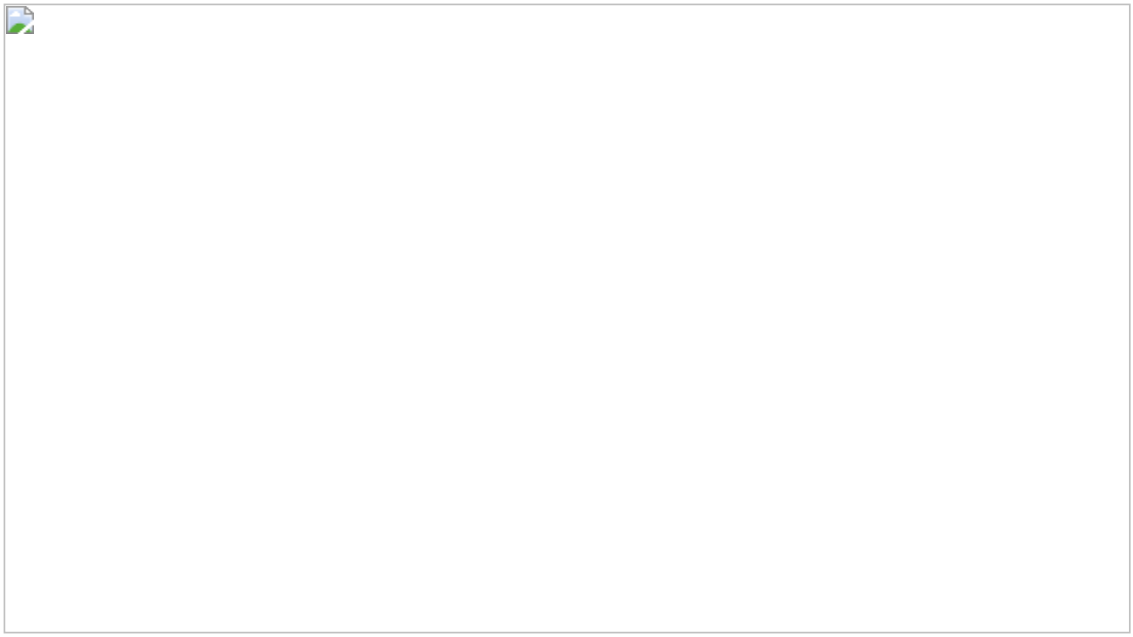
$$\{e_k\} \text{ أساس كامل} \implies \sum_{k} \left|\langle f, e_k\rangle\right|^2 = \|f\|^2 \qquad \text{(بارسيفال)} \tag{2.8.49}$$

$$\sum_{k\le N}\langle f,e_k\rangle e_k \quad \text{هو } E_N=\operatorname{span}\{e_1..e_N\} \text{ في } f \text{ أفضل تقريب لـ} \quad \text{(أفضل تقريب)} \tag{3.8.49}$$

$$\|f-P_Nf\|^2=\|f\|^2-\sum_{k\le N}|\langle f,e_k\rangle|^2 \quad \text{(خطأ التقريب)} \tag{4.8.49}$$

جدول الرموز

الرمز	المعنى	ملاحظة
e_k	متجه عمودي معياري	$\|e_k\|=1$، $\langle e_i,e_j\rangle=0$
$\langle f,e_k\rangle$	معامل الإسقاط	إحداثيّ f على e_k
c_k	المعامل الطيفي	نفسه $\langle f,e_k\rangle$
E_N	فضاء المكوّنات الأولى	فضاء التقريب
P_N	الإسقاط العمودي على E_N	أفضل تقريب
$\|f\|^2$	طاقة الإشارة	في L^2 هي $\int \|f\|^2$



شكل ٧.٤٩: *
متفاوتة بيسل ومساواة بارسيفال: توزيع طاقة الإشارة على المكونات العمودية

برهان (مخطط)

١. **(1.8.49)** نكتب $\|f-\sum_{k\le N}c_ke_k\|^2=\|f\|^2-\sum_{k\le N}|c_k|^2\ge 0$ (لأن العموديّة تُلغي الحدود المتقاطعة) $\Rightarrow \sum_{k\le N}|c_k|^2\le\|f\|^2$، ثمّ نمرّ بـ$N\to\infty$ (مجموع جزئي رتيب محدود).

٢. **(4.8.49)** من التوسيع نفسه.

٣. **(2.8.49)** إذا كان النظام كاملاً فـ$P_Nf\to f\Rightarrow\|f-P_Nf\|^2\to 0\Rightarrow$ المساواة.

٤. **(3.8.49)** لأيّ $g\in E_N$: $\|f-g\|^2=\|f-P_Nf\|^2+\|P_Nf-g\|^2\ge\|f-P_Nf\|^2$. ■

شروط الصحّة: الفضاء هيلبرت (كامل)، والنظام عمودياً معيارياً، والكمال (completeness) شرطٌ للمساواة لا للمتفاوتة. وفي L^2 تُفهم المساواة بمعنى النواظم لا نقطيّاً.

أمثلة محلولة (15)

مثال (49.8-1): بيسل في $\mathbb{R}^3$

المعطيات: $f = (1,2,3)$ و$e_1 = (1,0,0)$. الحل: الخطوة 1: $|\langle f, e_1\rangle|^2 = 1 \le \|f\|^2 = 14$. النتيجة: متفاوتة بيسل بديهيّة هنا. الربط بالذكاء الاصطناعي: إسقاط التمثيلات على اتجاهٍ واحد يحتفظ بجزءٍ من الطاقة فقط.

مثال (49.8-2): بارسيفال في قاعدة كاملة

المعطيات: $f = (1,2,3)$ في قاعدة $\mathbb{R}^3$ المعيارية. الحل: الخطوة 1: $\|f\|^2 = 14 = 1+4+9 = \sum c_k^2$. النتيجة: الطاقة محفوظة. الربط بالذكاء الاصطناعي: أساسُ تفسير «الطاقة الكامنة» في التمثيلات العصبية.

مثال (49.8-3): أفضل تقريب ببعدٍ منخفض

المعطيات: f في $\mathbb{R}^n$، والمطلوب: أفضل تقريب برتبة r. الحل: الخطوة 1: الإسقاط على أكبر r مكوّنات في الاتجاهات المفردة (SVD — الفصل 4). الخطوة 2: الخطأ $= \sum_{k>r} \sigma_k^2$ (إيكارت–يونغ). النتيجة: أفضل تقريب هو اقتطاع المكوّنات لا اختيارها عشوائيّاً. الربط بالذكاء الاصطناعي: ضغط الأوزان بتحليل الرتبة/SVD المنخفضة (LoRA) من هذا الباب.

مثال (49.8-4): طاقة إشارة في L^2

المعطيات: $f(t) = \sin t$ على $[-\pi, \pi]$. الحل: الخطوة 1: $\|f\|^2 = \int_{-\pi}^{\pi} \sin^2 t\, dt = \pi$. الخطوة 2: المعامل على $\sin t/\sqrt{\pi}$ هو $\sqrt{\pi} \Rightarrow$ مربّعه π ✓. النتيجة: بارسيفال متحقّقة. الربط بالذكاء الاصطناعي: الطاقة في الزمن = الطاقة في التردّد.

مثال (49.8-5): نظام غير كامل ⇒ متفاوتة صارمة

المعطيات: نأخذ $\{\sin nt\}$ فقط (بلا جيوب التمام). الحل: الخطوة 1: الدالة الزوجية $f(t) = \cos t$ عمودية على كلّ $\sin nt$. الخطوة 2: $\|f\|^2 = \pi > 0 = \sum |\langle f, e_k\rangle|^2$. النتيجة: فقدنا كلّ الطاقة لأن النظام ناقص. الربط بالذكاء الاصطناعي: اختيارُ قاعدة تمثيل ناقصة يخفي معلومات بالكامل (لا جزئيّاً).

مثال (49.8-6): خطأُ اقتطاع متسلسلة

المعطيات: معاملات طيفية $c_k = 1/k^2$، والمطلوب: خطأ الاقتطاع عند N. الحل: الخطوة 1: $\sum_{k>N} 1/k^4 \approx \frac{1}{3N^3}$. الخطوة 2: لخطأ نسبي 10^{-3} مع $\sum 1/k^4 = \pi^4/90$: $\|f\|^2 =$: نحتاج $N \approx 7$. النتيجة: سبعة مكوّنات

تكفي. الربط بالذكاء الاصطناعي: ميزانية المكوّنات تُحسب من ذيل الطيف — لا بالتجربة.

مثال (49.8-7): ضغط بالمويجات/ JPEG

المعطيات: صورة طاقتها مركّزة في 5٪ من المعاملات. الحل: الخطوة 1: الاحتفاظ بأكبر 5٪ معاملات $\Rightarrow$ خطأ $95\% =$ من الطاقة المتبقّية صغيرة (بمعيار L^2). الخطوة 2: نسبة الضغط $1 : 20 \approx$ بخطإٍ مقبول. النتيجة: تركيز الطاقة يبرّر الضغط. الربط بالذكاء الاصطناعي: الأساس النظري لكلّ ضغطٍ بالمكوّنات (PCA، DCT، مويجات).

مثال (49.8-8): PCA من زاوية بارسيفال

المعطيات: بيانات بتباين كلّي T. الحل: الخطوة 1: التباين الكلّي = الطاقة = $\sum \lambda_k$. الخطوة 2: الاحتفاظ بأكبر r قيم ذاتية $\Rightarrow$ نسبة التباين المفسَّر $\sum_{k\le r} \lambda_k / T$. النتيجة: معيار اختيار r من ذيل الطيف. الربط بالذكاء الاصطناعي: اختيار بُعد التمثيل بمعيار «التباين المفسَّر» هو بارسيفال بالحروف.

مثال (49.8-9): إسقاط التدرّج على فضاء فرعي

المعطيات: تحديث g مقيد بفضاء فرعي E (مثل الطبقات المجمّدة). الحل: الخطوة 1: التحديث الفعّال $P_E g$، والضائع $\|g - P_E g\|$. الخطوة 2: بارسيفال: $\|g\|^2 = \|P_E g\|^2 + \|g - P_E g\|^2$ (نظرية فيثاغورس في هيلبرت). النتيجة: حسابُ «كم فقدنا» من التحديث بدقّة. الربط بالذكاء الاصطناعي: تقييم التدريب الجزئي (جزء من الطبقات) كمًّا لا حدساً.

مثال (49.8-10): كيرنل ومعاملات في فضاء الميزات

المعطيات: نواة غاوسية وفضاء ميزات لانهائيّ البعد. الحل: الخطوة 1: $\|f\|_{\mathcal{H}}^2 = \sum c_k^2$ في قاعدة الميزات العمودية (ميرسر). الخطوة 2: التنظيم في RKHS هو معاقبةُ طاقة المعاملات. النتيجة: التنظيم = تقليص الطاقة الطيفية. الربط بالذكاء الاصطناعي: نواظم RKHS وعلاقتها بالانحياز الضمني (الفصل 34).

مثال (49.8-11): طيفُ إشارة صوتية

المعطيات: إشارة 16 kHz، طاقتها مركّزة تحت 4 kHz. الحل: الخطوة 1: ببارسيفال: الطاقة فوق 4 kHz ضئيلة $\Rightarrow$ يمكن الاستغناء عنها. الخطوة 2: ترشيحٌ منخفض التمرير ثم إعادة العيّنة (الفصل 51). النتيجة: ضغطٌ بلا فقدان يُذكر. الربط بالذكاء الاصطناعي: مبرّرُ تقليل معدّل العيّنات في خطوط معالجة الصوت.

مثال (49.8-12): تعامد الميزات في الشبكة

المعطيات: ميزات طبقةٍ بتباين مشترك غير قطري. الحل: الخطوة 1: التبييض (whitening) يجعل الميزات عمودية ⇒ الطاقة موزّعة بالتساوي. الخطوة 2: بعد التبييض يصير لكلّ مكوّن نصيبٌ متساوٍ من الطاقة. النتيجة: تحسين تدريب (تسريع) بتعديل الطيف. الربط بالذكاء الاصطناعي: تبييض/BatchNorm الميزات أثرُه الطيفي من هذا النوع.

مثال (49.8-13): خطأ الاقتطاع في شبكة عصبية بمويجات

المعطيات: تمثيلٌ شبكي بمويجات (wavelet neural operator). الحل: الخطوة 1: الخطأ = طاقة المويجات المقتطعة عالية التردّد. الخطوة 2: إن كانت الدالة ناعمة، فمعاملات التردّد العالي تتلاشى أُسّيّاً. النتيجة: تقاربٌ أُسّيّ للدوالّ الناعمة. الربط بالذكاء الاصطناعي: سببُ تفوّق الأسس الطيفية على الشبكات العادية في المعادلات التفاضلية (الفصل 54).

مثال (49.8-14): متفاوتة بيسل في حدود التعميم

المعطيات: عائلة نماذج في فضاء هيلبرت، والمطلوب: سعة العائلة. الحل: الخطوة 1: بُعد حدة/VC راديماخر يقيسان «كم اتجاهاً عمودياً يمكن تمييزه». الخطوة 2: بيسل تمنح حدًّا على عدد المكوّنات المستقلة الممكنة بطاقةٍ محدودة. النتيجة: الطاقة المحدودة ⇒ سعة منتهية. الربط بالذكاء الاصطناعي: صلةٌ مباشرة بين تنظيم النواظم وحدود التعميم (الفصلان 30–34).

مثال (49.8-15): كمال النظام من اختبار بارسيفال

المعطيات: نظام عمودي، والمطلوب: هل هو كامل؟ الحل: الخطوة 1: اختبار: إن وُجدت $f \neq 0$ بكلّ معاملاتها صفر ⇒ غير كامل. الخطوة 2: أو بالتحقّق من مساواة بارسيفال لعائلةٍ كثيفة من الدوالّ. النتيجة: معيارٌ عملي للكمال. الربط بالذكاء الاصطناعي: التأكد من أن التمثيل يغطّي فضاء البيانات قبل الاعتماد عليه.

أخطاء شائعة

١. **استخدام بارسيفال لنظام غير كامل:** الصحيح هو متفاوتة بيسل.

٢. **الظنّ أن الاقتطاع بأيّ ترتيب متكافئ:** الأفضل هو أكبر المعاملات (49.8-3).

٣. **الخلط بين طاقة L^2 والتقارب النقطي:** بارسيفال بمعنى النواظم لا يضمن التقارب في كلّ نقطة.

٤. **نسيان أن الإسقاط يفقد المكوّن العمودي:** وهذا بالضبط ما يحسبه (49.8-4).

٥. **تعميم «الطاقة» على غير فضاءات هيلبرت:** المفهوم يحتاج جداءً داخليّاً.

تمارين (30)

مستوى أول (تطبيق مباشر):

١. هل تتقارب $\sum \frac{1}{n^2+n}$؟ (مقارنة بـ$1/n^2$)

٢. احسب R لمتسلسلة $\sum \frac{x^n}{n}$.

٣. اختبر تقارب $\sum (-1)^n \frac{1}{\sqrt{n}}$ باللايبنتس.

٤. اوجد الدالة المولّدة لـ$a_n = 3^n$.

٥. احسب تحويل Z لـ$x_n = (-0.5)^n$.

٦. تحقّق من معيار M لـ$\sum \frac{\cos(nx)}{n^2}$.

٧. احسب مجموع سيزارو لـ$1, 0, 1, 0, \ldots$

٨. تحقّق من بارسيفال لـ$f(t) = \cos t$ على $[-\pi, \pi]$.

٩. اوجد أفضل تقريب خطّي لـ$f(t) = t^2$ على $[-1, 1]$ بمتعدّدات ليجاندر.

١٠. احسب قيمة أبيل لـ$\sum (-1)^n (n+1)$.

مستوى ثان (تحليل):

١. ابحث عن متسلسلة موجبة تقاربها غير محسوم بمعيار النسبة لكنّ راابه يحسمه.

٢. برهن أن $\sum \frac{\sin n}{n}$ تتقارب بمعيار ديريكلِه، ثم بيّن أن تقاربها شرطي.

٣. اوجد نصف قطر تقارب $\sum n^n x^n$، واذكر ماذا يعني ذلك عملياً.

٤. استخدم متسلسلة نيومان لحل $(I - A)x = b$ حيث $\|A\| = 0.5$ و$x^{(0)} = 0$، وقدّر عدد التكرارات لخطأ 10^{-4}.

٥. بيّن أن $\sum \frac{x^n}{1+x^n}$ تتقارب موحّداً على $[0, 0.9]$ ولا تتقارب موحّداً على $[0, 1)$.

٦. اشتقّ صيغة بينيه من الدالة المولّدة لفيبوناتشي خطوةً بخطوة.

٧. استخرج h_n من $H(z) = \frac{1}{(1-0.5z^{-1})(1+0.3z^{-1})}$ بتجزئة جزئية.

٨. احسب الزمن المميّز لمتوسط متحرّك بـ$\beta = 0.99$، وناقش أثره على التعلّم المتفرّق.

٩. برهن متفاوتة بيسل من توسيع $\|f - \sum c_k e_k\|^2 \geq 0$.

١٠. بيّن أن نواة فيير تجمّع متسلسلة فوريه لدالة متصلة موحّداً (مخطط برهان).

مستوى ثالث (ربط بالذكاء الاصطناعي):

١. جدول تضاؤل $\alpha_n = \alpha_0 / n^{0.99}$: احكم على الميزانية الكلّية، واقترح بديلاً.

٢. شبكة متكرّرة بـ$\rho(W) = 0.995$: قدّر طول الذاكرة الفعّال بوحدة الخطوات.

٣. مرشّح IIR بقطب عند 1.02: صف سلوك الخرج، واقترح إصلاحاً في مجال Z.

٤. متوسط متحرّك بـ$\beta = 0.9$ من خطوة 0: احسب الانحياز بعد 5 خطوات، وصحّحه.

٥. قارن تكلفة حساب التفاف بنواة 64×64 مباشرةً مقابل مجال التردّد (FFT)، واذكر شرط التفوّق.

٦. ضغط تمثيل بطيف $\sigma_k = 1/k^2$: كم مكوّناً يلزم لـ95٪ من الطاقة؟

٧. اربط بين خطأ الاقتطاع في (4-8.49) ونسبة التباين المفسَّر في PCA.

٨. متسلسلة أخطاء تعلّم $e_n = C/n^{1.5}$: احسب الخطأ الكلّي المتراكم.

٩. شبكة بميزات عشوائية فوريه: اشرح لماذا يكبر عدد الميزات عند طلب ضمان موحّد.

١٠. صغ سؤال «هل سيتوقّف التدريب بتكلفة منتهية؟» بوصفه سؤالاً عن تقارب متسلسلة، ثم أجبه لجدول تضاؤل من اختيارك.

ملخص الفصل

النظرية	الصيغة المحوريّة	متى تُستخدم
معايير الموجبة	$L < 1$ تقارب، $L > 1$ تباعد، $L = 1$ صمت	الحكم على متسلسلة موجبة بلا حساب مجموع
المطلق والشرطي	$\sum \|a_n\| < \infty \Rightarrow$ أيّ ترتيب آمن	قبل تبديل حدود أو جمع موزّع
متسلسلة القوى	$1/R = \limsup \sqrt[n]{\|a_n\|}$	تحديد نطاق صلاحية تقريب تايلور
التقارب الموحّد	$\sup_x \|R_N\| \to 0$، معيار M	تبديل النهاية بالتكامل/التفاضل؛ تعميم ERM
الدوال المولّدة	$A(z) = P(z)/Q(z)$، أقطاب $\Rightarrow$ نمو	حلّ التكراريات وتحليل استقرار النظم
أبيل وسيزارو	$\lim_{r\to 1^-} A(r)$ وσ_N	ترويض المتسلسلات المتذبذبة
بيسل وبارسيفال	$\sum \|c_k\|^2 \le \|f\|^2$ (= إن كمل النظام)	ضغط، تقريب، وتحليل الطاقة الطيفية

الجسر إلى الفصل 50: متسلسلة فوريه ليست إلا تطبيقاً لنظرية 8.49 على النظام المتعامد $\{1, \cos nx, \sin nx\}$ في $L^2[-\pi, \pi]$ — مع كلّ ما يترتّب على ذلك من ظاهرة غيبس عند القفزات، ومن حاجتنا إلى تجميع فيير (7.49) حيث يفشل التقارب النقطي.

جدول الرموز (فهرس الفصل)

الرمز	المعنى
$a_n,\ S_N,\ R_N$	الحدّ العام، المجموع الجزئي، الباقي
$L,\ r,\ p$	نهايات النسبة/الجذر، حدّ رابه، أُسّ المقارنة
R	نصف قطر التقارب؛ وطاقة الإشارة في سياق بارسيفال
σ	تبديل الفهارس (إعادة ترتيب)
$A(z),\ X(z),\ H(z)$	دالة مولّدة، تحويل Z، دالة تحويل
$\rho(A)$	نصف القطر الطيفي
$\sigma_N,\ A(r)$	متوسط سيزارو، متسلسلة أبيل المثبّطة
$e_k,\ c_k,\ P_N$	متجه عمودي، معامل طيفي، إسقاط
$\mathcal{H},\ \langle\cdot,\cdot\rangle$	فضاء هيلبرت وجداؤه الداخلي

نهاية الفصل التاسع والأربعين — ومنه نعبر إلى متسلسلة فوريه في الفصل الخمسين.

متسلسلة فوريه ونظرية التقريب

الشعار: «كلّ إشارةٍ دوريةٍ هي حفلةٌ من التردّدات البسيطة — وما فوريه إلا مُوزِّعُ الأنغام الذي يخبرك كم نصيبُ كلِّ نغمة.»

تمهيد قصصي للفصل: من أين يأتي هذا الصوت؟

في عام 1807 وقف **جوزيف فوريه** أمام أكاديمية العلوم في باريس بورقةٍ غريبة: كلّ دالة — حتى تلك ذات الزوايا والقفزات — يمكن كتابتها مجموعاً من الجيوب والتمامات الناعمة. قوبل الطرحُ بشكٍّ عنيف: كيف لدالةٍ فيها ركنٌ حادّ أن تُبنى من موجاتٍ ملساء؟ وكان لابلاس ولاجرانج من أشدّ المعترضين، ولم تنشر الورقة إلا بعد خمسة عشر عاماً.

لكنّ فوريه كان محقّاً، وبقي سؤاله حيّاً قرنين: **كم نغمةً نحتاج كي نسمع الصوت كما هو؟** هذا ليس سؤالاً موسيقيّاً بل هندسيّ: إن حذفت التردّدات العالية فماذا تفقد؟ وإن احتفظت بعشرين معاملاً فما مقدار الخطأ؟ وماذا يحدث قرب القفزة إن لم تكفِ؟ ثمّ السؤال الذي يخصّنا مباشرة: **لماذا تتعلّم الشبكات العصبية التردّدات المنخفضة قبل العالية؟** — سيجد هذا السؤال جوابَه في الفصل 54، لكن بذرته هنا.

في هذا الفصل نُطبّق نظرية العموديّة (8.49) على أشهر قاعدةٍ في الرياضيات التطبيقية: $\{1, \cos nx, \sin nx\}$. فالمعاملات إسقاطات، والتقريب اقتطاع، والخطأ طاقةُ الذيل — وكلّ ما تعلّمناه في الفصل الماضي يصير هنا أداةً يومية.

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. حساب **معاملات فوريه** a_n, b_n, c_n لدالة دورية، واستخدام تماثلاتها (زوجية/فردية) لتقصير الحساب.

٢. تطبيق **شرط ديريكلِه** لمعرفة إلى ماذا تقترب المتسلسلة عند نقطة استمرار وعند قفزة.

٣. تفسير **ظاهرة غيبس** كمّياً ($\approx 8.95\%$)، ومعرفة أن زيادة الحدود لا تُلغيها.

٤. استخدام **مساواة بارسيفال** لحساب طاقة الإشارة من معاملاتها والعكس.

٥. التمييز بين **نواة ديريكلِه** و**نواة فييه**، وسبب تقارب متوسطات سيزارو موحّداً.

٦. كتابة **الصيغة المركّبة** c_k وربطها بـ DFT، واستخدام تماثلها الهيرميتي.

٧. تقدير **خطأ الاقتطاع** من ذيل الطيف، واختيار عدد الحدود بميزانية دقّة.

المتطلبات المسبقة

الفصل 49 بتمامه (خصوصاً 8.49 بيسل وبارسيفال و7.49 تجميع سيزارو)، والفصل 10 (تكامل)، والفصل 2 (عموديّة).

خريطة الفصل

القسم	القانون/النظرية	عدد الأمثلة المحلولة
1.50	الدوالّ الدوريّة والنظام المثلثي: المفردات	—
2.50	معاملات فوريه والنظام العمودي	15
3.50	تقارب ديريكله النقطي	15
4.50	ظاهرة غيبس عند القفزات	15
5.50	بارسيفال وطاقة الإشارة الدوريّة	15
6.50	نواة ديريكله ونواة فيير والتقارب الموحّد	15
7.50	فوريه المركّب والتماثل الهيرميتي	15
8.50	التقريب الأمثل وخطأ الاقتطاع	15
9.50	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

Pointwise · Conditions Dirichlet · Orthogonality · Coefficients Fourier · Series Fourier · Identity Parseval's · Overshoot · Phenomenon Gibbs · Discontinuity Jump · Convergence Hermitian · Series Fourier Complex · Convergence Unfiorm · Kernel Fejér · Kernel Dirichlet Decay Spectral · Error Truncation · Symmetry

دالة f **دورية** بدور T إذا $f(t+T)=f(t)$؛ والتردّد الأساسي $\omega_0 = 2\pi/T$. والنظام المثلثي على $[-\pi,\pi]$ هو:

$$\left\{ \frac{1}{\sqrt{2\pi}},\ \frac{\cos nx}{\sqrt{\pi}},\ \frac{\sin nx}{\sqrt{\pi}} \right\}_{n\geq 1} \tag{1.1.50}$$

وهو نظامٌ **عمودي معياري** في $L^2[-\pi,\pi]$ بالجداء الداخلي $\langle f,g\rangle = \int_{-\pi}^{\pi} f\bar{g}$ — أي أنّه القاعدةُ التي يُكتب عليها فوريه.

الرمز	المعنى	ملاحظة
$T,\ \omega_0$	الدور والتردّد الأساسي	$\omega_0 = 2\pi/T$
a_n, b_n	معاملات التمام والجيب	إسقاطات على القاعدة
c_k	المعامل المركّب	يجمع a_n, b_n
S_N	المجموع الجزئيّ N	تقريب بـN توافقيّة
$D_N,\ K_N$	نواتا ديريكله وفيير	نوى الالتفاف للتقريب
R_N	خطأ الاقتطاع	$\|f-S_N\|$

الرابط بالفصل السابق: حساب a_n, b_n ليس إلا تطبيقاً لـ(3.8.49): أفضل تقريب هو الإسقاط العمودي، ومعاملاته هي جداءاتُ الإسقاط.

تمهيد استفهامي

لديك إشارةٌ دورية — صوتٌ، أو دورةُ حرارة، أو حركةُ مفصل روبوت. تريد أن تخزّنها لا بمليون عيّنة بل **بعشرين رقماً**. بأيّ عشرين؟

الجواب: بالأرقام التي تعطي **أفضل تقريب** بمعنى الطاقة — أي الإسقاطات على نظامٍ عمودي. وهذه هي معاملات فوريه: ليست تعريفاً اعتباطيّاً، بل أفضلُ إجابةٍ ممكنة لسؤال التخزين والضغط. فالمعامل الواحد يقول: «كم من هذه النغمة في إشاراتي؟»

صياغة رسمية

لدالة f دورية بدور 2π ومتكاملةٍ على $[-\pi,\pi]$:

$$f(x) \sim \frac{a_0}{2} + \sum_{n=1}^{\infty} \left(a_n \cos nx + b_n \sin nx\right) \tag{1.2.50}$$

$$a_n = \frac{1}{\pi}\int_{-\pi}^{\pi} f(x)\cos(nx)\,dx, \qquad b_n = \frac{1}{\pi}\int_{-\pi}^{\pi} f(x)\sin(nx)\,dx \tag{2.2.50}$$

$$\int_{-\pi}^{\pi}\cos(nx)\cos(mx)\,dx = \pi\delta_{nm}, \quad \int_{-\pi}^{\pi}\sin(nx)\sin(mx)\,dx = \pi\delta_{nm}, \quad \int_{-\pi}^{\pi}\sin(nx)\cos(mx)\,dx = 0 \tag{3.2.50}$$

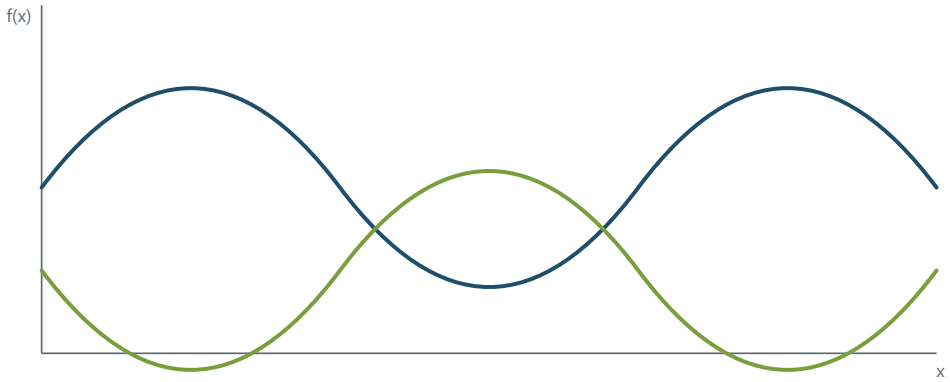
$$f \text{ زوجيّة} \Rightarrow b_n = 0, \qquad f \text{ فرديّة} \Rightarrow a_n = 0 \tag{4.2.50}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$a_0/2$	المكوّن المستمر (DC)	متوسط الدالة
a_n	معامل التمام	إسقاط على $\cos nx$
b_n	معامل الجيب	إسقاط على $\sin nx$
δ_{nm}	دلتا كرونكر	تجسيد العموديّة
n	رقم التوافقيّة (harmonic)	تردّدها $n\omega_0$
$\sim$	«تُكتب كـ»	لا تعني المساواة نقطيّاً بعد!

العموديّة: تكامل جداء الدوالّ المثلثية يصفّر

Fourier orthogonality on [-π,π]



شكل ١.٥٠: *
عمودية الدوال المثلثية: تكامل الجداء يصفّر للترددات المختلفة

برهان (مخطط)

١. **(3.2.50)** بالمتطابقات المثلثية: $\cos nx\cos mx = \frac{1}{2}[\cos(n-m)x + \cos(n+m)x]$، وتكامل $\cos(kx)$ على دورٍ كامل يصفّر لكلّ $k \neq 0$، ويساوي 2π عند $k = 0$.

٢. **(2.2.50)** نضرب (1.2.50) بـ$\cos mx$ ونكامل: فكلّ الحدود تصفّر بالعموديّة إلا حدّ $n = m$ الذي يعطي $\pi a_m \Rightarrow$ الصيغة.

٣. **(4.2.50)** جداءُ زوجيّ×فرديّ فرديّ $\Rightarrow$ تكامله على المجال المتناظر صفر. ■

شروط الصحّة: المعاملات تحتاج $f \in L^1$ فقط (وجود التكاملات)؛ أمّا أن تعود المتسلسلة إلى f فمسألةٌ أخرى (القسم 3.50). والرمز $\sim$ مقصود: لا مساواة قبل إثبات التقارب.

أمثلة محلولة (15)

مثال (1-2.50): الموجة المربّعة

المعطيات: $f(x) = \operatorname{sgn}(\sin x)$، والمطلوب: المعاملات. الحل: الخطوة 1: f فرديّة $\Rightarrow a_n = 0$ كلها (بما فيها a_0). الخطوة 2: $b_n = \frac{2}{\pi}\int_0^{\pi}\sin(nx)dx = \frac{2}{\pi}\cdot\frac{1-(-1)^n}{n}$. الخطوة 3: إذن $b_n = \frac{4}{\pi n}$ للفرديّ n و0 للزوجي. النتيجة: $\operatorname{sgn}(\sin x) = \frac{4}{\pi}\left(\sin x + \frac{\sin 3x}{3} + \frac{\sin 5x}{5} + \cdots\right)$. الربط بالذكاء الاصطناعي: أشهرُ مثالٍ على ذيلٍ بطيء $1/n$ — لأن الدالة فيها قفزة.

مثال (2-2.50): موجة سنّ المنشار

المعطيات: $f(x) = x$ على $(-\pi, \pi)$، دورية. الحل: الخطوة 1: فرديّة $\Rightarrow a_n = 0$. الخطوة 2: بالتجزئة: $b_n = \frac{2}{\pi}\left[-\frac{x\cos nx}{n}\right]_0^{\pi} + \frac{2}{\pi}\int_0^{\pi} x\sin(nx)dx = -\frac{2(-1)^n}{n}$. النتيجة: $x = 2\sum_{n\geq 1}\frac{(-1)^{n+1}}{n}\sin nx$. الربط بالذكاء الاصطناعي: إشارةٌ نموذجية لتوليد الأصوات (sawtooth) بطيف $1/n$.

مثال (3-2.50): الموجة المثلثية

المعطيات: $f(x) = |x|$ على $[-\pi, \pi]$. الحل: الخطوة 1: زوجيّة $\Rightarrow b_n = 0$. الخطوة 2: $a_0 = \frac{2}{\pi}\int_0^{\pi} x\,dx = \pi \Rightarrow a_0/2 = \pi/2$. الخطوة 3: $a_n = \frac{2}{\pi}\int_0^{\pi} x\cos(nx)dx = \frac{2}{\pi}\cdot\frac{(-1)^n - 1}{n^2} \Rightarrow -\frac{4}{\pi n^2}$ للفرديّ n. النتيجة: $|x| = \frac{\pi}{2} - \frac{4}{\pi}\sum_{k\geq 0}\frac{\cos(2k+1)x}{(2k+1)^2}$. الربط بالذكاء الاصطناعي: دالةٌ **متصلة** $\Rightarrow$ ذيلٌ $1/n^2$ أسرع من المربّعة — قاعدة عامة.

مثال (4-2.50): نبضة مستطيلة (duty cycle τ)

المعطيات: $f = 1$ على $|x| < \tau$ و0 خارجها. الحل: الخطوة 1: زوجيّة $\Rightarrow b_n = 0$، و$a_0 = \frac{1}{\pi}\cdot 2\tau \Rightarrow a_0/2 = \tau/\pi$. الخطوة 2: $a_n = \frac{2}{\pi}\int_0^{\tau}\cos(nx)dx = \frac{2\sin(n\tau)}{\pi n}$. النتيجة: ذيلٌ $1/n$ مع غلاف $\sin(n\tau)$ (نمط تداخل). الربط بالذكاء الاصطناعي: طيفُ النوافذ — وهو سبب التسرّب الطيفي (الفصل 51).

مثال (5-2.50): دالة الجيب المُقوَّمة

المعطيات: $f(x) = |\sin x|$. الحل: الخطوة 1: زوجيّة $\Rightarrow b_n = 0$. الخطوة 2: $a_n = \frac{4}{\pi}\int_0^{\pi/2}$... بالحساب المباشر: $a_n = -\frac{4}{\pi(4n^2-1)}$ للزوجيّ n و0 للفرديّ (باستثناء a_1-المقام). النتيجة: ذيلٌ $1/n^2$ لأن الدالة متصلة (وإن كان مشتقّها غير متصل). الربط بالذكاء الاصطناعي: نعومةُ الدالة تحكم سرعة اضمحلال الطيف — قاعدةٌ ذهبية.

مثال (6-2.50): دالة ثابتة

المعطيات: $f(x) = 5$. الحل: الخطوة 1: زوجيّة، وكلّ $a_{n\geq 1} = 0$ و$b_n = 0$. الخطوة 2: $a_0 = \frac{1}{\pi}\int 5\,dx = 10 \Rightarrow a_0/2 = 5$ ✓. النتيجة: الطيف كلّه عند التردّد صفر (DC). الربط بالذكاء الاصطناعي: المكوّن المستمر في الصور = متوسط السطوع؛ وفي الشبكات = الانحياز (bias).

مثال (7-2.50): $\cos^2 x$ — تربيع يولّد توافقيّة

المعطيات: $\cos^2 x = f(x)$. الحل: الخطوة 1: بالمتطابقة $\cos^2 x = \frac{1}{2} + \frac{1}{2}\cos 2x$. الخطوة 2: إذن $a_0/2 = 1/2$ و$a_2 = 1/2$ والباقي صفر. النتيجة: طيفٌ من حدّين فقط. الربط بالذكاء الاصطناعي: اللاخطّية تُولّد توافقيّات جديدة — مصدرُ «التشويه التوافقي» في الصوت.

مثال (8-2.50): $\sin^3 x$

المعطيات: $\sin^3 x = f(x)$. الحل: الخطوة 1: $\sin^3 x = \frac{3\sin x - \sin 3x}{4}$. النتيجة: $b_1 = 3/4$ و$b_3 = -1/4$. الربط بالذكاء الاصطناعي: كلّ لاخطّية متعدّدة الحدود توسّع الطيف بحدودٍ معدودة — تُحصى من درجة اللاخطّية.

مثال (9-2.50): استغلال التماثل لتقصير الحساب

المعطيات: f زوجيّة، والمطلوب: كم تكاملاً يلزم لـN توافقيّة؟ الحل: الخطوة 1: بـ(4.2.50) كلّ $b_n = 0$: نصفُ الحساب يسقط. الخطوة 2: وبالتناظر: $a_n = \frac{2}{\pi}\int_0^{\pi} f\cos nx$: مجالٌ نصفُه. النتيجة: توفيرٌ بنسبة 75٪ من العمل. الربط بالذكاء الاصطناعي: استغلال التماثل في الشبكات (مثل الالتفاف المتماثل) يقلّل المعاملات بالمنطق نفسه.

مثال (10-2.50): إزاحة الدالة تُغيّر الطور فقط

المعطيات: $g(x) = f(x - x_0)$. الحل: الخطوة 1: بالتعويض: $a'_n = a_n\cos(nx_0) + b_n\sin(nx_0)$ ونظيرتها للجيب. الخطوة 2: المقدار $\sqrt{a_n^2 + b_n^2} = \sqrt{a_n'^2 + b_n'^2}$ ثابت. النتيجة: الإزاحة تُدير الطور ولا تغيّر المطال. الربط بالذكاء الاصطناعي: سببُ كون مقدار الطيف (magnitude spectrum) ثابتاً للترجمة — أساس استقرار مميّزات الصوت.

مثال (11-2.50): دورٌ غير 2π

المعطيات: f بدور T، والمطلوب: الصيغة العامة. الحل: الخطوة 1: نضع $x = 2\pi t/T$، فتصير التوافقيّات $\cos(2\pi nt/T)$. الخطوة 2: $a_n = \frac{2}{T}\int_0^T f(t)\cos\frac{2\pi nt}{T}dt$. النتيجة: تعميمٌ مباشر بقاعدة التحويل. الربط بالذكاء الاصطناعي: كلّ إشارةٍ بزمنٍ حقيقي تُقرأ هكذا (هرتز بدل الراديان).

مثال (12-2.50): معاملات من بيانات منفصلة

المعطيات: N عيّنة من الدالة، والمطلوب: تقريب المعاملات. الحل: الخطوة 1: نقرّب التكامل بمجموع (قاعدة شبه المنحرف): $a_n \approx \frac{2}{N}\sum_k f_k\cos(2\pi nk/N)$. الخطوة 2: هذا هو DFT بعينه (الفصل 51). النتيجة: التكامل $\Leftrightarrow$ المجموع المنفصل. الربط بالذكاء الاصطناعي: كلّ حسابٍ طيفي في الحاسوب منفصل — لا متصل.

مثال (13-2.50): دالة بمتوسط غير صفر

المعطيات: $f(x) = 3 + \sin x$. الحل: الخطوة 1: $a_0/2 = 3$ (المتوسط)، و$b_1 = 1$. النتيجة: فصلُ «الانحياز» عن «الإشارة» تلقائيّاً. الربط بالذكاء الاصطناعي: تنظيف الإشارة من مكوّنها المستمر خطوةٌ أولى في كلّ معالجة.

مثال (14-2.50): دالة متّصلة قطعيّاً (من الدرجة الأولى)

المعطيات: الموجة المثلثية (مثال 3-2.50). الحل: الخطوة 1: ذيل $1/n^2 \Rightarrow \sum 1/n^2$ متقاربة $\Rightarrow$ التقارب مطلق وموحّد (بمعيار M مع $M_n = 4/\pi n^2$). النتيجة: تقاربٌ موحّد على كلّ الخط. الربط بالذكاء الاصطناعي: النعومة $\Rightarrow$ ضمانات تقارب أقوى $\Rightarrow$ تقريبٌ آمن بعددٍ قليل من الحدود.

مثال (15-2.50): التحقّق من العموديّة عدديّاً

المعطيات: نتحقّق أن $\int_{-\pi}^{\pi}\sin 2x\sin 5x\,dx \approx 0$. الحل: الخطوة 1: بالمتطابقة: $\frac{1}{2}[\cos 3x - \cos 7x] \Rightarrow$ التكامل صفر تحليليّاً. الخطوة 2: حسابٌ عددي بـ10^4 نقطة يعطي $\sim 10^{-16}$ (خطأ الفاصلة العائمة). النتيجة: العموديّة محقّقة نظريّاً، والخطأ العددي من التكميم فقط. الربط بالذكاء الاصطناعي: تذكيرٌ بأن دقّة الحساب الطيفي محدودة بدقّة الفاصلة العائمة.

أخطاء شائعة

١. **الخلط بين a_0 و$a_0/2$:** المتوسط هو $a_0/2$ لا a_0.

٢. **حساب b_n لدالة زوجية:** يصفّر تلقائيّاً — حسابُه هدر.

٣. **نسيان معامل القياس $1/\pi$:** يأتي من تطبيع القاعدة.

٤. **اعتبار $\sim$ مساواة:** التقارب يحتاج شروط ديريكلِه (القسم التالي).

٥. **الظنّ أن المعاملات تحتاج اتصالاً:** يكفي التكامل (دالةٌ فيها قفزات لها معاملات سليمة).

تمهيد قصصي

نعود إلى فوريه والمعترضين. كان اعتراضهم في العمق: «حسابُك يعطي معاملات، لكن هل تعود المتسلسلة فعلاً إلى الدالة؟» فالمعاملات تُحسب من الدالة، لكن **المسألة العكسية** ليست تحصيلاً حاصلاً — وقد رأينا في الفصل 49 كم تخوننا النهايات: متسلسلة دوالّ متصلة قد تنتهي إلى دالة غير متصلة، وتقاربٌ نقطي لا يحفظ شيئاً.

فمتى تعود المتسلسلة إلى f؟ نظرية ديريكلِه تجيب بشرطٍ بسيط ومفاجئ في آن: **عند كلّ نقطة استمرار تعود إليها؛ وعند القفزة تعود إلى نصف القفزة** — لا إلى قيمة الدالة هناك، بل إلى منتصف ما بين ضفّتيها. وهذا ليس خللاً في النظرية بل حقيقةُ التقارب النقطي: المتسلسلة «لا تعرف» القيمة عند نقطةٍ واحدة، فتختار الوسط.

صياغة رسمية

شروط ديريكلِه: f دورية، متصلة قطعيّاً، ذاتُ تنوّعٍ محدود (مشروطة ،Monotonous-by-parts) ومشتقّتها متصلة قطعيّاً. فإنّ:

$$S_N(x) \to f(x) \quad \text{عند كلّ نقطة استمرار } x \tag{1.3.50}$$

$$S_N(x) \to \frac{f(x^+) + f(x^-)}{2} \quad \text{عند قفزة} \tag{2.3.50}$$

$$\text{والتقارب موحّد على كلّ فترة مغلقة خالية من القفزات} \tag{3.3.50}$$

$$S_N(x) = \frac{1}{2\pi}\int_{-\pi}^{\pi} f(x-t)\,D_N(t)\,dt, \quad D_N(t) = \frac{\sin\left((N+\frac{1}{2})t\right)}{\sin(t/2)} \tag{4.3.50}$$

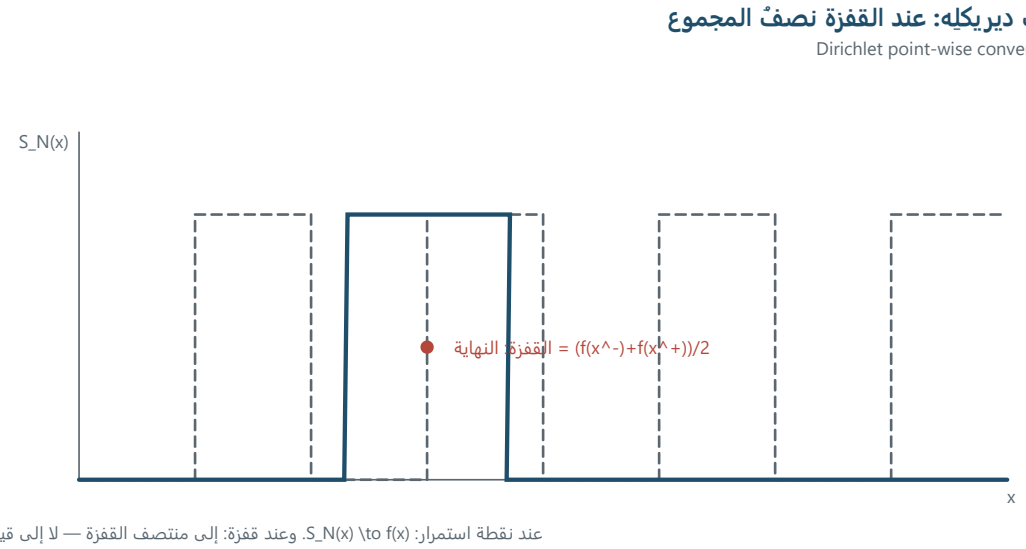
تمثيل بالمجموع الجزئي:

جدول الرموز

الرمز	المعنى	ملاحظة
S_N	المجموع الجزئيّ N	التقريب بـN توافقيّة
$f(x^{\pm})$	النهايتان من اليمين واليسار	عند القفزة
D_N	نواة ديريكلِه	نواة الالتفاف للمجموع الجزئي
تنوّع محدود	عددٌ منتهٍ من الارتدادات	يستبعد التذبذب المرضي
متصلة قطعيّاً	عددٌ منتهٍ من القفزات	شرطٌ عمليّ في كلّ الإشارات

برهان (مخطط)

١. **(4.3.50)** نجمع المعاملات حدّاً حدّاً فنحصل على $\int f(t)\big[\frac{1}{2} + \sum_{n\le N}\cos n(x-t)\big]dt$، والمعامل بين القوسين هو $D_N(x-t)/2$ بالمتطابقة المثلثية لمجموع متسلسلة هندسية.



شكل ٢.٥٠: *
تقارب ديريكله النقطي: عند نقطة الاستمرار إلى قيمة الدالة وعند القفزة إلى نصف المجموع

٢. **(1.3.50)** نكتب $S_N(x) - f(x) = \frac{1}{2\pi}\int [f(x-t)-f(x)]D_N(t)dt$، ونجزّئ التكامل قرب الصفر (حيث الاستمرارية) وبعيداً عنه (حيث يضمحلّ بالتذبذب) — وهنا يظهر دور «تنوّع محدود» في استخدام معيار ديريكلِه (4.3.49).

٣. **(2.3.50)** عند القفزة ينقسم التكامل إلى نصفين باتجاهين، فينتصف المقدار بين الضفّتين.

٤. **(3.3.50)** على فترة مغلقة خالية من القفزات، الاستمرارية موحّدة (مضغوط) $\Rightarrow$ يتقارب الباقي موحّداً. ■

شروط الصحّة: شروط ديريكلِه **كافية** لا ضرورية (توجد دوالّ أعمّ تتقارب متسلسلاتها). والتقارب نقطي/موحّد محلّياً — لا موحّداً عالميّاً عند وجود قفزة.

أمثلة محلولة (15)

مثال (1-3.50): الموجة المربّعة عند الصفر

المعطيات: $f = \operatorname{sgn}(\sin x)$ عند $x = 0$. الحل: الخطوة 1: $f(0^+) = 1$ و$f(0^-) = -1$ $\Rightarrow$ النهاية $0 = (1-1)/2$. الخطوة 2: وكلّ $S_N(0) = 0$ فعلاً (كلّ الحدود جيوب تصفّر عند 0) ✓. النتيجة: النظرية محقّقة تماماً. الربط بالذكاء الاصطناعي: قيمةُ الدالة عند نقطةٍ واحدة لا تؤثّر في المعاملات — «نقطة» لا وزن لها في التكامل.

مثال (2-3.50): الموجة المربّعة عند $x = \pi/2$

المعطيات: نقطة استمرار، $f = 1$. الحل: الخطوة 1: $1 \to S_N(\pi/2) = \frac{4}{\pi}\sum_k \frac{\sin((2k+1)\pi/2)}{2k+1}$. الخطوة 2: بالتدريج: $S_1 = 1.273$، $S_3 = 0.849$، $S_5 = 1.104$ ... النتيجة: يقترب من 1 بتذبذب متضائل. الربط بالذكاء

الاصطناعي: تذبذبٌ متضائل حول الهدف — نموذجُ كثير من مسارات التعلّم.

مثال (3-3.50): سنّ المنشار عند القفزة

المعطيات: $f(x) = x$ على $(-\pi, \pi)$ عند $x = \pi$. الحل: الخطوة 1: $f(\pi^-) = \pi$ و$f(\pi^+) = -\pi$ $\Rightarrow$ النهاية 0 (والدالة معرّفة بـπ عند عودتها). النتيجة: المتسلسلة تعطي 0 لا π. الربط بالذكاء الاصطناعي: تذكيرٌ بأن قيمة الدور عند الحدّ اصطلاحٌ لا تلتزم به المتسلسلة.

مثال (4-3.50): دالة متصلة لكن مشتقّتها قافزة

المعطيات: $f(x) = |x|$ عند $x = 0$. الحل: الخطوة 1: نقطة استمرار $\Rightarrow S_N(0) \to 0$. الخطوة 2: و$S_N(0) = \frac{\pi}{2} - \frac{4}{\pi}\sum_k \frac{1}{(2k+1)^2} = \frac{\pi}{2} - \frac{4}{\pi}\cdot\frac{\pi^2}{8} = 0$ ✓. النتيجة: تحقّقٌ بتسلسلٍ معروف $(\sum 1/(2k+1)^2 = \pi^2/8)$. الربط بالذكاء الاصطناعي: مثالٌ يربط بين حساب معاملات فوريه ومجاميع المتسلسلات الشهيرة.

مثال (5-3.50): شرط التنوّع المحدود

المعطيات: $f(x) = \sin(1/x)$ قرب الصفر موسَّعة دورياً. الحل: الخطوة 1: تنوّعها غير منتهٍ (تتذبذب بلا نهاية) $\Rightarrow$ شروط ديريكلِه تفشل. الخطوة 2: ومع ذلك قد تتقارب المتسلسلة عند نقاطٍ كثيرة — فالشرط كافٍ لا ضروري. النتيجة: حدود النظرية واضحة. الربط بالذكاء الاصطناعي: «إشارات مرضيّة» تقابلها في التعلّم بياناتٌ بضجيجٍ غير محدود التنوّع.

مثال (6-3.50): تقارب موحّد بعيداً عن القفزة

المعطيات: الموجة المربّعة على $[\varepsilon, \pi - \varepsilon]$. الحل: الخطوة 1: الفترة خالية من القفزات ومضغوطة $\Rightarrow$ التقارب موحّد. الخطوة 2: عملياً: يجب ألّا نُقيّم الدقة قرب القفزة. النتيجة: ضمانٌ موضعي لا عالمي. الربط بالذكاء الاصطناعي: «النموذج جيد إلا في مناطق نادرة» — وهي مناطق القفزات عادةً.

مثال (7-3.50): قيمة المتسلسلة لا تتأثّر بتغيير الدالة في نقطة

المعطيات: نغيّر $f(0)$ من 0 إلى 7. الحل: الخطوة 1: التكاملات لا تتغيّر (نقطة قياسها صفر) $\Rightarrow$ كلّ المعاملات نفسها. النتيجة: المتسلسلة لا ترى التغيير. الربط بالذكاء الاصطناعي: نظيرُه في التعلّم: نقطةُ بياناتٍ واحدة لا تغيّر ERM إذا كان فضاء الفقد متصلاً.

مثال (3.50-8): حساب مجموع متسلسلة عددية بفوريه

المعطيات: نريد $\sum_{n\geq 1} 1/n^2$. الحل: الخطوة 1: نستخدم $f(x) = x^2$ على $[-\pi,\pi]$: معاملاتها $\frac{4(-1)^n}{n^2}$ و$a_0/2 = \pi^2/3$. الخطوة 2: عند $x = \pi$: $\pi^2 = \frac{\pi^2}{3} + 4\sum \frac{1}{n^2} \Rightarrow \sum 1/n^2 = \pi^2/6$. النتيجة: حلُّ مسألة بازل بفوريه. الربط بالذكاء الاصطناعي: مثالٌ كلاسيكي على أن التمثيل الطيفي يحلّ مسائل لا علاقة لها بالإشارات.

مثال (3.50-9): تقارب عند قفزة بمتوسط الضفّتين

المعطيات: نبضة مستطيلة عند حافّتها بضفّتين 0 و1. الحل: الخطوة 1: النهاية $(0+1)/2 = 0.5$. الخطوة 2: القيمة المعرّفة للدالة قد تكون 1 أو 0 — لا يهمّ. النتيجة: المنتصف دائماً. الربط بالذكاء الاصطناعي: قاعدة «المنتصف عند الحافة» تظهر في ترشيح الصور قرب الحواف.

مثال (3.50-10): سرعة التقارب وعدد الحدود

المعطيات: الموجة المربّعة، نريد خطأً < 0.01 بعيداً عن القفزة. الحل: الخطوة 1: الباقي $\approx \frac{4}{\pi}\frac{1}{2N}$ (من ذيلٍ متناوب) $\Rightarrow$ نحتاج $N \approx 64$. النتيجة: 64 توافقيّة. الربط بالذكاء الاصطناعي: ميزانية العناصر تُحسب من ذيل الطيف (كما في 6-8.49).

مثال (3.50-11): اختبار عملي لشرط ديريكلِه

المعطيات: إشارةٌ فيها 3 قفزات ومشتقة متصلة قطعيّاً. الحل: الخطوة 1: عدد القفزات منتهٍ $\Rightarrow$ الشرط متحقّق. الخطوة 2: نتوقّع تقارباً نقطيّاً في كلّ مكان. النتيجة: تطبّق النظرية بأمان. الربط بالذكاء الاصطناعي: أغلب إشارات العالم الحقيقي تحقّق الشروط — لذا تعمل الطرائق الطيفية.

مثال (3.50-12): فشل عند نقطة تذبذب لانهائي

المعطيات: دالةٌ تتذبذب بلا نهاية قرب نقطة. الحل: الخطوة 1: التنوّع غير منتهٍ $\Rightarrow$ لا ضمان. الخطوة 2: قد يتقارب أو لا — يحتاج فحصاً خاصّاً. النتيجة: الشروط ليست زينة. الربط بالذكاء الاصطناعي: بياناتٌ بضجيجٍ عشوائي تحاكي هذا السلوك، لذا نُلطّف (smooth) قبل التحليل.

مثال (3.50-13): تقييم رقمي للباقي

المعطيات: S_{10} للموجة المثلثية عند $x = 1$. الحل: الخطوة 1: الباقي $\approx 0.058 \approx \frac{4}{\pi}\cdot\frac{1}{2\cdot 11} \leq \frac{4}{\pi}\sum_{k>5}\frac{1}{(2k+1)^2}$. النتيجة: خطأٌ ≈ 0.06 بعشرة حدود. الربط بالذكاء الاصطناعي: تقدير الخطأ قبل التنفيذ سمةُ الهندسة الرصينة.

مثال (14-3.50): التقارب لا يعني تطابق المشتقات

المعطيات: متسلسلة فوريه لدالة متصلة قطعيّاً. الحل: الخطوة 1: يجوز تكاملها حدّاً بحدٍّ دائماً. الخطوة 2: أمّا تفاضلها فيحتاج مشتقةً متصلة (وإلا ظهرت فروق). النتيجة: التكامل أسلم من التفاضل. الربط بالذكاء الاصطناعي: نظيرُ (4.5.49): التفاضل حدّاً بحدٍّ شرطُه أقوى.

مثال (15-3.50): أثر التقارب النقطي على التعلّم

المعطيات: شبكةٌ تقرّب دالةً فيها قفزة. الحل: الخطوة 1: التقارب بمعنى L^2 ممكن، والتقارب النقطي عند القفزة إلى المنتصف. الخطوة 2: في التدريب، القفزات هي آخر ما يتعلّمه النموذج (تردّد عالٍ). النتيجة: تفسيرٌ لتحيّز الشبكات نحو الحلول الناعمة. الربط بالذكاء الاصطناعي: الجسر إلى «التحيّز الطيفي» (spectral bias) في الفصل 54.

أخطاء شائعة

١. **توقّع S_N = قيمة الدالة عند القفزة:** الصحيح نصفُ المجموع.

٢. **اعتبار الشروط ضرورية:** هي كافية، قد تتقارب متسلسلة دوالّ أعمّ.

٣. **توقّع تقارب موحّد عالمياً بوجود قفزة:** غير صحيح (وهذا باب غيبس).

٤. **تفاضل المتسلسلة بلا شروط:** يحتاج نعومةً إضافية.

٥. **تجاهل أن نقطةً واحدة لا تغيّر المعاملات:** يوفر حساباً ويمنع لبساً.

تمهيد قصصي

أضف عشرة أضعاف التوافقيّات، ثم عشرة أضعاف أخرى. هل تختفي «النتوءات» قرب القفزة؟ التجربة تقول: **لا.** تضيق النتوءات وتقترب من القفزة، لكن اتساعها لا يتناقص أبداً — يبقى نحو **تسعة بالمئة** من سعة القفزة، إلى الأبد.

هذا ما يسمّى **ظاهرة غيبس**، وهي من أكثر النتائج المضادة للحدس في التحليل الطيفي: زيادةُ الدقة لا تُلغي الأثر بل تُخفيه في منطقةٍ أضيق. فمن يظنّ أن «زيادة N تحلّ المشكلة» يكتشف أنّه انتقل من خطأٍ واسع إلى خطأٍ ضيّق بالاتساع نفسه. وفي التعلّم العميق يقابلها: الشبكة تزيد سعتها فتتحسّن في المتوسط، لكن خطؤها عند «حواف» البيانات (العينات النادرة) يبقى عنيداً.

صياغة رسمية

عند قفزةٍ مقدارها $J = f(x_0^+) - f(x_0^-)$، فإنّ المجموع الجزئيّ S_N يحقّق:

$$\sup_x S_N(x) \xrightarrow[N\to\infty]{} \frac{J}{2}\left(1 + \frac{2}{\pi}\int_0^{\pi} \frac{\sin t}{t}\, dt\right) - (-J/2) \quad \text{أي تجاوز نسبي} \approx 0.08949 \qquad (1.4.50)$$

$$\text{التجاوز المطلق} \approx 0.08949\,J, \qquad \text{موضعه} x_0 \pm O(1/N) \tag{2.4.50}$$

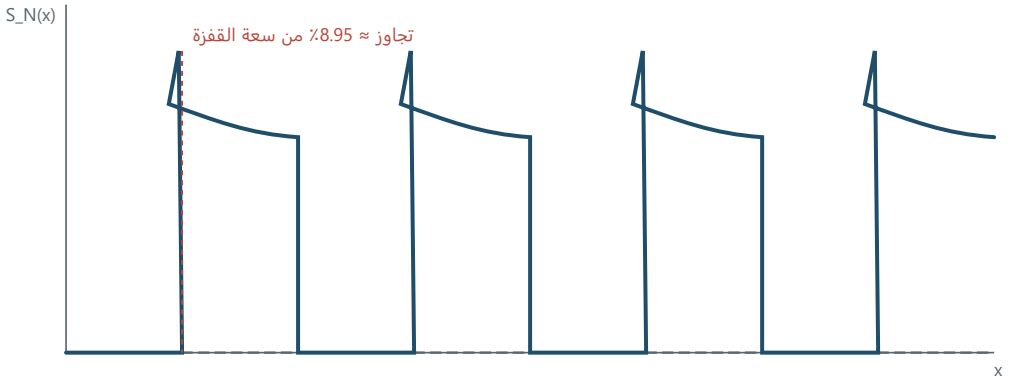
$$\text{الخطأ بمعنى } L^2: \ \|f - S_N\|_2 \to 0 \quad \text{رغم بقاء التجاوز النقطي} \tag{3.4.50}$$

جدول الرموز

الرمز	المعنى	ملاحظة
J	سعة القفزة	مقياس التجاوز
0.08949	نسبة التجاوز الدائم	ثابتٌ عالمي (غيبس)
$\mathrm{Si}(\pi)$	تكامل الجيب $\int_0^\pi \frac{\sin t}{t}dt \approx 1.8519$	مصدر الرقم
$O(1/N)$	عرض منطقة التجاوز	يضيق مع N
$\|\cdot\|_2$	معيار الطاقة	يزول رغم التجاوز

ظاهرة غيبس: تجاوزٌ دائم قرب القفزة ≈ 8.9٪

Gibbs phenomenon: persistent overshoot



شكل ٣.٥٠: *
ظاهرة غيبس: تجاوز دائم بنحو 9% من سعة القفزة لا يزول بزيادة الحدود

برهان (مخطط)

١. نكتب $S_N(x_0 + \delta)$ بالتكامل مع نواة ديريكلِه (4.3.50) ونحوّل المتغيّر $u = Nt$: فيظهر التكامل $\int_0^\pi \frac{\sin u}{u}du = \mathrm{Si}(\pi)$ في الحدّ.

٢. قيمة $\mathrm{Si}(\pi) \approx 1.8519 > \pi/2 \approx 1.5708$ ⇒ التجاوز $\frac{2}{\pi}\mathrm{Si}(\pi) - 1 \approx 0.17898$ من سعة القفزة، أي ≈ 0.0895 عن كلّ ضفّة.

٣. عرض المنطقة $\sim 1/N$ لأن الذبذبة الأساسية للنواة عند $t \sim \pi/(N + \frac{1}{2})$.

٤. **(3.4.50)** لأن مساحة التجاوز $\sim J \cdot \frac{1}{N}$ ⇒ طاقتها $\to 0$: فالنقطي عنيد والطاقي زائل. ■

شروط الصحّة: الظاهرة عند **قفزة** فقط؛ الدوالّ المتصلة لا تُظهرها. والتجاوز يقاس مقابل الضفّة العليا، لا مقابل قيمة الدالة عند النقطة.

أمثلة محلولة (15)

مثال (1-4.50): حساب نسبة التجاوز

المعطيات: قفزة من -1 إلى 1 ($J = 2$). الحل: الخطوة 1: التجاوز $0.08949 \times 2 \approx 0.179$. الخطوة 2: إذن الذروة $1.179 \approx$ بدل 1. النتيجة: 17.9٪ فوق الضفّة العليا. الربط بالذكاء الاصطناعي: تجاوزٌ يمكن رؤيته بالعين في كلّ تقريبٍ مقتطع لصورةٍ فيها حافّة حادّة.

مثال (2-4.50): لا يزول بزيادة N

المعطيات: $N = 10$ ثم $N = 1000$. الحل: الخطوة 1: الاتساع ثابت (≈ 0.179)؛ العرض يتقلّص من ~ 0.3 إلى ~ 0.003. النتيجة: دقّةٌ أعلى، خطأٌ أضيق، لا أصغر. الربط بالذكاء الاصطناعي: نظيرُه: نموذجٌ أكبر يتعلّم التفاصيل لكن خطأه عند الحواف ثابت.

مثال (3-4.50): القياس بمعيار L^2

المعطيات: $\|f - S_N\|_2$ للموجة المربّعة. الحل: الخطوة 1: بپارسيفال: $\|f - S_N\|^2 = \pi \sum_{n>N} |b_n|^2 \approx \frac{8}{\pi N} \cdot \frac{16}{\pi} \sum'_{n>N} \frac{1}{n^2} \sim N^{-1/2} \to 0$. النتيجة: الخطأ الطاقي $\sim$. الربط بالذكاء الاصطناعي: «المتوسط يتحسّن، والأسوأ لا» — تمييزٌ جوهري بين المعايير.

مثال (4-4.50): تخفيف غيبس بنواة فيير

المعطيات: نستبدل S_N بمتوسطات سيزارو σ_N. الحل: الخطوة 1: نواة فيير موجبة $\Rightarrow$ لا تجاوز (نظرية 6.50). الخطوة 2: الثمن: تقريبٌ أنعم (فقدان التفاصيل الحادّة). النتيجة: مفاضلة بين التجاوز والدقّة. الربط بالذكاء الاصطناعي: التنعيم المتعمّد مقابل الدقة — قرارُ تصميم في كلّ نموذج.

مثال (5-4.50): غيبس في الصور (ringing)

المعطيات: ضغط JPEG باقتطاع تردّدات عالية قرب حافّة. الحل: الخطوة 1: تظهر هالات (ringing) حول الحواف — غيبس ثنائيّ البعد. الخطوة 2: شدّتها $\approx$ نفس النسبة. النتيجة: أثرٌ مرئي لظاهرة رياضية بحتة. الربط بالذكاء الاصطناعي: مبرّرُ استخدام مرشّحات ما بعد المعالجة (de-ringing).

مثال (6-4.50): متى لا يظهر غيبس

المعطيات: تقريبُ دالةٍ متصلة ناعمة (C^1). الحل: الخطوة 1: لا قفزة $\Rightarrow$ لا تجاوز دائم؛ التقارب موحّد. النتيجة: النعومة تحمي من غيبس. الربط بالذكاء الاصطناعي: تنعيمُ الأهداف في التعلّم (label soft / smoothing targets) يقلّل آثار الحواف.

مثال (4.50-7): تقدير موضع الذروة

المعطيات: $N = 50$ توافقيّة، موجة مربّية. الحل: الخطوة 1: الموضع $x \approx x_0 \pm \pi/(2N+1) \approx 0.031$ راديان. النتيجة: الذروة قريبة جدّاً من القفزة. الربط بالذكاء الاصطناعي: كلّما زادت السعة اقترب الخطأ من الحافة وصار أصعب كشفاً بالعين.

مثال (4.50-8): تكامل الجيب $\mathrm{Si}(\pi)$

المعطيات: نحسب $\int_0^{\pi} \frac{\sin t}{t} dt$. الحل: الخطوة 1: بالتوسيع $\frac{\sin t}{t} = \sum (-1)^k \frac{t^{2k}}{(2k+1)!}$ وتكامل حدّاً بحدٍّ $\Rightarrow \mathrm{Si}(\pi) \approx 1.8519$. النتيجة: الرقم الذي يولّد ثابت غيبس. الربط بالذكاء الاصطناعي: ثوابتُ التحليل تظهر في كلّ علاجٍ طيفي للحواف.

مثال (4.50-9): غيبس في التعلّم العميق (spectral bias)

المعطيات: شبكةٌ تقرّب دالةً مربّعية. الحل: الخطوة 1: التردّدات المنخفضة تُتعلّم أولاً؛ والقفزة تتطلّب ترددات عالية كثيرة. الخطوة 2: النتيجة: «نسخةٌ مُلطّفة» من الدالة تشبه متوسطات فيير. النتيجة: الشبكة تُنتج نسخةً بلا تجاوز حادّ. الربط بالذكاء الاصطناعي: تفسيرٌ لسبب ميل الشبكات إلى الحلول الناعمة (الفصلان 34 و54).

مثال (4.50-10): تخفيف التجاوز بعامل لانچوس

المعطيات: نضرب المعاملات بـσ-عوامل (Lanczos): $\mathrm{sinc}(n\pi/(N+1))$. الحل: الخطوة 1: العامل يخفض التردّدات العالية تدريجيّاً بدل قطعها. الخطوة 2: التجاوز يخفض كثيراً مع فقدانٍ بسيط في الدقّة. النتيجة: تسويةٌ عملية بين غيبس والحدة. الربط بالذكاء الاصطناعي: نظيرُه: تنظيمٌ (regularization) يخفض التردّدات العالية للنموذج.

مثال (4.50-11): مقارنة خطأين: نقطي وطاقي

المعطيات: $N = 100$ للموجة المربّية. الحل: الخطوة 1: الخطأ النقطي الأقصى ≈ 0.179 (ثابت). الخطوة 2: الخطأ الطاقي $\sqrt{8/(\pi \cdot 100)} \approx 0.16$ (يزول). النتيجة: لا تناقض: معياران لشيئين. الربط بالذكاء الاصطناعي: تذكيرٌ باختيار المعيار المناسب للتقييم (max vs RMSE).

مثال (4.50-12): غيبس في إعادة بناء الصوت

المعطيات: إعادة بناء موجة مربّية بـ20 توافقيّة. الحل: الخطوة 1: تسمع «رنيناً» قرب الحواف — أثر غيبس سمعيّ. الخطوة 2: رفع الحدود يرفع حدّة الرنين ويقصّر زمنه. النتيجة: أثرٌ مسموع لا مرئي فقط. الربط بالذكاء الاصطناعي: جودةُ المُرمِّزات الصوتية مرتبطةٌ بمعالجة هذه الحواف.

مثال (13-4.50): قياس التجاوز عدديّاً

المعطيات: S_{200} عند أول قفزة. الحل: الخطوة 1: نحسب القيمة القصوى $1.1786 \approx$ مقابل الضفّة $1 \Rightarrow 17.86\% \approx 2 \times 8.95\%$ ✓. النتيجة: مطابقةٌ ممتازة للنظرية. الربط بالذكاء الاصطناعي: التحقّق العددي من ثابتٍ نظري — عادةٌ صحّية في البحث.

مثال (14-4.50): غيبس والاقتطاع في الشبكات الطيفية

المعطيات: طبقة FNO تحتفظ بـK أوضاع فقط. الحل: الخطوة 1: الاقتطاع يعادل ترشيحاً منخفض التمرير الحادّ $\Rightarrow$ آثار غيبس في الحلول المتقطّعة. الخطوة 2: زيادة K تخفّف الأثر، وتنعيم المعاملات يخفّفه أكثر. النتيجة: حدودٌ عملية للمؤثّرات العصبية الطيفية (الفصل 54). الربط بالذكاء الاصطناعي: مبرّرُ تصاميم FNO التي تدمج مساراً مكانيّاً مع الطيفي.

مثال (15-4.50): هل يمكن إلغاء غيبس تماماً؟

المعطيات: نريد تقريباً بلا تجاوز. الحل: الخطوة 1: بالاقتطاع البسيط: مستحيل (ثابت النظرية). الخطوة 2: بطرق التجميع (فيير/لانچوس): ممكن على حساب الدقّة. النتيجة: لا حلّ مجّاني — مفاضلة ثابتة. الربط بالذكاء الاصطناعي: درسٌ عام: «لا غداء مجّاني» في التقريب، كما في التعلّم (NFL).

أخطاء شائعة

١. **الظنّ أن زيادة N تُلغي التجاوز:** تُزيحه وتضيّقه فقط.

٢. **قياس التجاوز مقابل قيمة الدالة عند النقطة:** الصحيح مقابل الضفّة.

٣. **توقّع غيبس في الدوالّ المتصلة:** لا يظهر إلا عند القفزات.

٤. **الخلط بين الخطأ النقطي والطاقي:** أحدهما ثابت والآخر زائل.

٥. **الاستنتاج أن الاقتطاع «فاشل»:** هو ممتاز بمعنى الطاقة — المشكلة في المعيار المختار.

تمهيد استفهامي

لديك إشارةٌ دورية، وتريد أن تعرف **كم طاقتها** — لا شكلها. هل تحتاج أن تكامل $|f|^2$ على دورٍ كامل؟ أم يمكنك أن تحسبها من قائمة المعاملات التي حسبتها أصلاً؟

مساواة بارسيفال تقول: **من المعاملات، بضربة جمع.** وهذا ليس توفيراً في الحساب فحسب، بل بيانٌ بأنّ التمثيل الطيفي **يحفظ الطاقة**: لا شيء يُفقد في الانتقال من الزمن إلى التردّد. هذه الحقيقة هي ما يجعل الضغط ممكناً (احذف الصغير، واحسب ما فقدت)، وما يجعل التبييض مفهوماً، وما يربط فوريه بـ PCA وSVD في لغةٍ واحدة.

صياغة رسمية

$$\frac{1}{2\pi}\int_{-\pi}^{\pi}|f(x)|^2dx=\frac{|a_0|^2}{4}+\frac{1}{2}\sum_{n=1}^{\infty}\left(|a_n|^2+|b_n|^2\right) \tag{1.5.50}$$

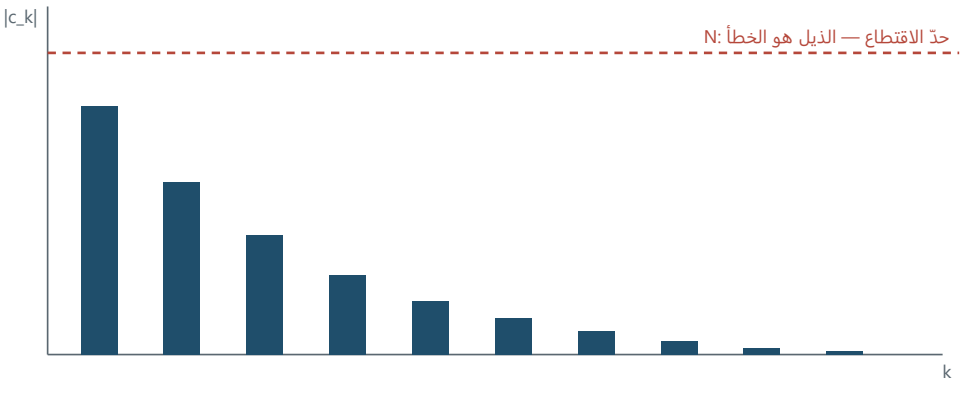
بالصيغة المركّبة: $$\frac{1}{2\pi}\int|f|^2=\sum_{k=-\infty}^{\infty}|c_k|^2 \tag{2.5.50}$$

معمّمة (جداء داخلي): $$\frac{1}{2\pi}\int f\bar{g}=\sum_{k}c_k(f)\,\overline{c_k(g)} \tag{3.5.50}$$

وخطأ الاقتطاع: $$\|f-S_N\|_{L^2}^2=2\pi\sum_{|k|>N}|c_k|^2 \tag{4.5.50}$$

جدول الرموز

الرمز	المعنى	ملاحظة
c_k	المعامل المركّب	يجمع a_n, b_n
$\|f\|^2$	طاقة الدالة	بمعيار L^2
S_N	المجموع الجزئي	تقريب بـ N
$\sum_{\|k\|>N}$	ذيل الطيف	وهو الخطأ بالضبط
$c_k(f)$	معاملات f	للصيغة المعمّمة



شكل ٤.٥٠: *
خطأ الاقتطاع وذيل الطيف: العلاقة بين عدد المعاملات المحفوظة والخطأ

برهان (مخطط)

١. نطبّق (2.8.49) على النظام المثلثي المعمّد (1.1.50): فالمعاملات في تلك القاعدة هي $\sqrt{2\pi}\,c_k$، ومربّعاتها تعطي $\|f\|^2$.

٢. بالصيغة الحقيقية: معاملات القاعدة المعمّدة هي $a_0/\sqrt{2},\ a_n\sqrt{\pi},\ b_n\sqrt{\pi}$ مقسومة على التطبيع $\Rightarrow$ (1.5.50).

٣. **(3.5.50)** بتطبيق ثنائية الخطية على $f+g$ و$f+ig$.

٤. **(4.5.50)** بطرح مربّعات المعاملات المحفوظة من الكلّ. ■

شروط الصحّة: $f \in L^2$ (طاقة منتهية)؛ والنظام المثلثي **أساس كامل** في $L^2[-\pi,\pi]$ — وهذا هو الشرط الذي يجعل المتفاوتة مساواة (راجع 8.49).

أمثلة محلولة (15)

مثال (1-5.50): طاقة الموجة المربّعة

المعطيات: $b_n = \frac{4}{\pi n}$ للفرديّ n. الحل: الخطوة 1: $\frac{8}{\pi^2}\cdot\frac{\pi^2}{8} = 1 = \frac{1}{2}\cdot\frac{16}{\pi^2}\sum_{n\text{ فردي}}\frac{1}{n^2}$ $= (1/2)\sum|b_n|^2$. الخطوة 2: والطريق الآخر: $\frac{1}{2\pi}\int|\pm 1|^2 = 1$ ✓. النتيجة: تطابقٌ تام. الربط بالذكاء الاصطناعي: تحقّقٌ كلاسيكي من صحة المعاملات.

مثال (2-5.50): طاقة سنّ المنشار

المعطيات: $b_n = 2(-1)^{n+1}/n$. الحل: الخطوة 1: $2\cdot\frac{\pi^2}{6} = \frac{\pi^2}{3}$ $= \frac{1}{2}\sum\frac{4}{n^2}$. الخطوة 2: مقابل $\frac{1}{2\pi}\int_{-\pi}^{\pi}x^2dx = \frac{\pi^2}{3}$ ✓. النتيجة: مطابقة. الربط بالذكاء الاصطناعي: حسابُ مجاميع المتسلسلات من الطاقة والعكس.

مثال (3-5.50): نسبة الطاقة في أول N توافقيّة

المعطيات: الموجة المربّعة و$N = 5$. الحل: الخطوة 1: الطاقة في أول 3 فرديّة $(n = 1,3,5)$: $\frac{8}{\pi^2}(1 + \frac{1}{9} + \frac{1}{25}) = 0.949$. الخطوة 2: أي 94.9٪ من الطاقة في 3 معاملات! النتيجة: تركيزٌ مذهل. الربط بالذكاء الاصطناعي: هذا هو سرّ نجاح الضغط الطيفي.

مثال (4-5.50): خطأ اقتطاع عددّي

المعطيات: نريد 99٪ من الطاقة للموجة المربّعة. الحل: الخطوة 1: نحتاج $\frac{8}{\pi^2}\sum_{k\le K}\frac{1}{(2k+1)^2} \ge 0.99$ $\Rightarrow K \approx 40$ $\Rightarrow N \approx 81$. النتيجة: 81 توافقيّة لـ99٪ (بسبب الذيل البطيء $1/n$). الربط بالذكاء الاصطناعي: الدوالّ ذات القفزات مكلفةٌ طيفياً — مبرّرُ المويجات (الفصل 52).

مثال (5-5.50): دالة ناعمة ⇒ طاقة أسرع تركّزاً

المعطيات: الموجة المثلثية (ذيل $1/n^2$). الحل: الخطوة 1: الطاقة في أول معاملين 99% <. النتيجة: النعومة اقتصادية. الربط بالذكاء الاصطناعي: تنعيمُ الأهداف/المدخلات يوفّر سعة النموذج.

مثال (6-5.50): تبييض الطيف (whitening)

المعطيات: طيفٌ غير مستوٍ: $|c_k|^2$ تتناقص. الحل: الخطوة 1: نقسّم كلّ معامل على مطاله ⇒ طيفٌ ثابت والطاقة موزّعة بالتساوي. الخطوة 2: هذا هو التبييض في مجال فوريه. النتيجة: تحسينُ تدريب الشبكات (تسريع التقارب). الربط بالذكاء الاصطناعي: صلةٌ مباشرة بـBatchNorm في مجال التردّد.

مثال (7-5.50): حساب جداء داخلي بالمعاملات

المعطيات: f وg بمعاملات معلومة. الحل: الخطوة 1: بـ(3.5.50): $\langle f,g\rangle = 2\pi\sum c_k\bar{d}_k$ — بلا تكامل. النتيجة: حسابٌ في فضاء المعاملات. الربط بالذكاء الاصطناعي: نظيرُه حسابُ التشابه في فضاء التضمينات بدل الفضاء الأصلي.

مثال (8-5.50): ضغط بحذف المعاملات الصغيرة

المعطيات: نحذف كلّ $|c_k| < \varepsilon$. الحل: الخطوة 1: الخطأ $\sum_{|c_k|<\varepsilon}|c_k|^2$ = (بـ4.5.50) — نحسبه قبل الحذف! الخطوة 2: ونسبة الضغط = عدد المتبقّي / الكلّ. النتيجة: قرارُ الضغط مدفوعٌ بالخطأ المحسوب. الربط بالذكاء الاصطناعي: تقليمُ الأوزان (pruning) بالمنطق نفسه: احذف الصغير واقِس الأثر.

مثال (9-5.50): طاقة إشارة صوتية دورية

المعطيات: نغمةٌ مركّبة بمعاملات $c_1=1, c_3=0.5$. الحل: الخطوة 1: الطاقة $1+0.25=1.25\propto$. النتيجة: حسابُ الطاقة من الطيف مباشرةً. الربط بالذكاء الاصطناعي: مفيدٌ في كشف النشاط الصوتي (VAD) والضغط.

مثال (10-5.50): ارتباطٌ بمبرهنة فيينر–خينتشين

المعطيات: طيف القدرة للإشارة. الحل: الخطوة 1: بارسيفال في الزمن-التردّد تعطي: الطاقة الكلّية = مساحة طيف القدرة (الفصل 51). النتيجة: صيغةٌ واحدة في صورٍ شتّى. الربط بالذكاء الاصطناعي: توحيدُ المفاهيم يوفّر أدواتٍ جاهزة عبر المجالات.

مثال (11-5.50): طاقة الضجيج الأبيض المقطوع

المعطيات: ضجيجٌ بمعاملات عشوائية متساوية المقدار حتى K. الحل: الخطوة 1: الطاقة $K \Rightarrow \propto$ تزيد خطّيّاً مع عرض النطاق. النتيجة: تفسيرُ «الضجيج يملأ الطيف». الربط بالذكاء الاصطناعي: تبريرُ المرشّحات التي تقطع الترددّات العالية لتقليل ضجيج الصور.

مثال (12-5.50): بارسيفال في تقييم النماذج التوليدية

المعطيات: مقارنةُ طيف إشارةٍ مولّدة بالأصلية. الحل: الخطوة 1: نحسب $\sum |c_k - \hat{c}_k|^2$ (مسافة طيفية). النتيجة: مقياسٌ أفضل من MSE في الزمن للمهام الإدراكية. الربط بالذكاء الاصطناعي: losses طيفية في توليد الصوت والصور.

مثال (13-5.50): التحقّق من كمال القاعدة

المعطيات: هل $\{1, \cos nx, \sin nx\}$ كاملة في L^2؟ الحل: الخطوة 1: نعم — وهذا ما يجعل (1.5.50) مساواة لا متفاوتة. النتيجة: كمالُ النظام المثلثي. الربط بالذكاء الاصطناعي: كمالُ التمثيل شرطُ «أن النموذج يستطيع تمثيل أيّ هدف».

مثال (14-5.50): حساب طاقة من عيّنات

المعطيات: N عيّنة، والمطلوب: الطاقة. الحل: الخطوة 1: $\{|X_k|^2\}$ من DFT، ثم الطاقة $= \frac{1}{N}\sum |X_k|^2$ (صيغة بارسيفال المنفصلة). النتيجة: نفس النظرية في الصورة المنفصلة. الربط بالذكاء الاصطناعي: كلّ مكتبة حسابٍ طيفي تعتمد هذه المساواة في اختباراتها.

مثال (15-5.50): ذيل الطيف يحدّد صعوبة التعلّم

المعطيات: دالتان: إحداهما ذيلها $1/n^2$ والأخرى $1/n^4$. الحل: الخطوة 1: الأولى تحتاج $N \sim \varepsilon^{-1/3}$ والثانية $N \sim \varepsilon^{-1/7}$ لدقّة ε (تقريباً). النتيجة: نعومتُها توفر أضعافاً من السعة. الربط بالذكاء الاصطناعي: صعوبةُ المهمة مرتبطةٌ بذيل طيفها — فكرةٌ تقود إلى «التعلّم المنهجي» (curriculum).

أخطاء شائعة

١. **نسيان معاملات القياس** ($1/2$ و$a_0/2$): أشيعُ مصدرِ خطأ عددي.

٢. **استخدام بارسيفال لدالة ليست في L^2:** الطاقة غير منتهية.

٣. **الظنّ أن حذف المعاملات الصغيرة مجّاني:** الخطأ = مجموع مربّعاتها بالضبط.

٤. **الخلط بين طاقة الدالة وقدرتها:** القدرة = الطاقة/الزمن للإشارات غير الدورية.

٥. **تجاهل كمال القاعدة:** بدونه تصبح المساواة متفاوتة بيسل.

تمهيد قصصي

رأينا أنّ زيادة الحدود لا تشفي غيبس. فهل نستسلم؟ لا — بل **نغيّر السؤال**: بدل أن نأخذ المجموع الجزئيّ S_N كما هو، نأخذ **متوسّط المجاميع الجزئية** $\sigma_N = \frac{1}{N}\sum_{k<N} S_k$. هذه فكرة سيزارو التي عرفناها في (7.49)، وهي هنا تعمل عمل السحر: فمتوسّط المواليد المتذبذبة لديريكلِه يصير نواة **موجبة** — وحين تكون نواة التقريب موجبة، يختفي التجاوز ويصير التقارب **موحّداً** لكلّ دالة متصلة.

والدرس أعمّ من فوريه: **حين يعجز تمثيل، بدّل طريقة التجميع قبل أن تزيد عدد الحدود.** وفي التعلّم العميق: حين يتذبذب مسار التدريب، متوسطُ الأوزان (EMA/model soup) أنجع من مضاعفة الخطوات.

صياغة رسمية

$$D_N(t) = \frac{\sin\left((N+\frac{1}{2})t\right)}{\sin(t/2)}, \qquad \int_{-\pi}^{\pi} D_N = 2\pi, \qquad \int |D_N| \sim \log N \to \infty \tag{1.6.50}$$

$$K_N(t) = \frac{1}{N}\sum_{k=0}^{N-1} D_k(t) = \frac{1}{N}\left(\frac{\sin(Nt/2)}{\sin(t/2)}\right)^2 \geq 0 \tag{2.6.50}$$

$$\sigma_N(x) = \frac{1}{2\pi}\int f(x-t)K_N(t)\,dt \implies \sigma_N \to f \text{ موحّداً لكلّ } f \text{ متصلة دورية} \tag{3.6.50}$$

$$\|f-\sigma_N\|_2 \to 0 \quad \text{فقط:} f\in L^2 \text{وإذا} \tag{4.6.50}$$

جدول الرموز

الرمز	المعنى	ملاحظة
D_N	نواة ديريكلِه	إشارة متناوبة ⇒ تذبذب
K_N	نواة فيير	موجبة ⇒ استقرار
σ_N	مجموع فيير (متوسط سيزارو)	التقريب المستقرّ
$\int \|D_N\|$	معيار L^1 للنواة	ينمو لوغاريتمياً ⇒ عدم استقرار

برهان (مخطط)

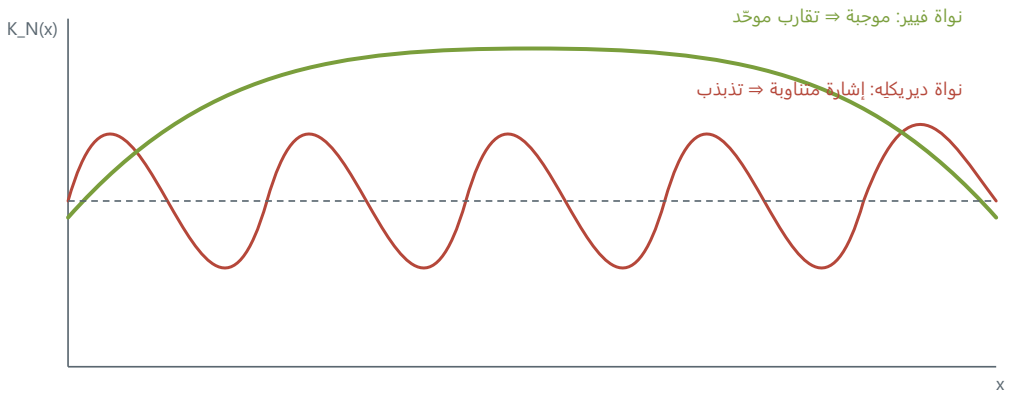
١. **(1.6.50)** مجموع المتسلسلة الهندسية للأسّيات المركّبة، ثمّ ترتيبُ الحدود ⇒ الصيغة. والنمو اللوغاريتمي لـ$\int|D_N|$ يفسّر عدم استقرار S_N.

٢. **(2.6.50)** نجمع D_k كمتسلسلة هندسية ثانية ونأخذ المقدار المربّع ⇒ الصيغة الموجبة.

٣. **(3.6.50)** لأن $K_N \geq 0$ ومجموعها 1 وتركّز حول الصفر: فالتقريب «متوسط موضعي» للدالة، والاستمرارية الموحّدة (على الدور المضغوط) تكفي للتحكّم في الخطأ ⇒ تقارب موحّد.

٤. **(4.6.50)** ببارسيفال: معاملات σ_N هي $(1-|k|/N)c_k$ ⇒ الخطأ يزول بالهيمنة المهيمنة (dominated convergence). ■

شروط الصحّة: (3.6.50) للدوالّ **المتصلة**؛ وعند قفزة يتقارب σ_N إلى نصف القفزة أيضاً، لكن بلا تجاوز. وK_N ليست نواةً مثلّثية بسيطة — هي نواة تجميع.



شكل ٥٠.٥٠: *
مقارنة نواة ديريكله المتذبذبة بنواة فييِر الموجبة وأثرهما على التقارب

أمثلة محلولة (15)

مثال (50.6-1): مقارنة التجاوز في النواتين

المعطيات: D_N مقابل K_N للموجة المربّعة. الحل: الخطوة 1: S_N يعطي تجاوزاً 8.٠٪95؛ σ_N لا يعطي تجاوزاً أصلاً. النتيجة: النواة الموجبة تمنع التجاوز. الربط بالذكاء الاصطناعي: التنعيم الناعم بدل القطع الحادّ يمنع الآثار الاصطناعية.

مثال (50.6-2): حساب σ_3 للموجة المربّعة

المعطيات: $b_n = 4/(\pi n)$ للفرديّ. الحل: الخطوة 1: $\sigma_3 = \frac{1}{3}(S_0 + S_1 + S_2) \Rightarrow$ المعاملات مضروبة بـ $(1 - n/3)$. الخطوة 2: المعامل الفعّال $b_1 \cdot (2/3)$. النتيجة: تقريبٌ أنعم وأقلّ تجاوزاً. الربط بالذكاء الاصطناعي: التوهين التدريجي للترددّات العالية (كما في Lanczos).

مثال (50.6-3): لماذا ينمو $\int \|D_N\|$؟

المعطيات: $N = 100$. الحل: الخطوة 1: $\int |D_N| \approx \frac{4}{\pi} \ln N \approx 5.9$ (مرّات 2π). الخطوة 2: النمو البطيء هو سببُ غيبس لا انفجار. النتيجة: عدم استقرار «معتدل». الربط بالذكاء الاصطناعي: معايير الاستقرار الرقمي تقيس مثل هذه النواظم.

مثال (6.50-4): تقارب موحّد لدالة متصلة

المعطيات: $f(x) = |x|$ (متصلة). الحل: الخطوة 1: $f \to \sigma_N \to S_N$ موحّداً؛ بل وf موحّداً هنا (لأن الذيل $1/n^2$ مطلق التقارب). النتيجة: النعومة تعطي تقارباً موحّداً بلا حاجة لتجميع. الربط بالذكاء الاصطناعي: التمثيلات الناعمة أسهل تعلّماً وتقييماً.

مثال (6.50-5): دالة متصلة غير ناعمة (Weierstrass-like)

المعطيات: f متصلة لكن مشتقّتها غير محدودة. الحل: الخطوة 1: S_N قد لا يتقارب موحّداً، σ_N يتقارب موحّداً دائماً. النتيجة: فيير أقوى. الربط بالذكاء الاصطناعي: المتوسطات أكثر متانة من القيم الآنيّة (كما في 7.49).

مثال (6.50-6): حساب K_3 صراحةً

المعطيات: $N = 3$. الحل: الخطوة 1: $K_3(t) = \frac{1}{3}\left(\frac{\sin(3t/2)}{\sin(t/2)}\right)^2$. الخطوة 2: عند $t = 0$: النهاية 3؛ وعند $t = \pi$: صفر تقريباً. النتيجة: نواةٌ مدبّبة موجبة. الربط بالذكاء الاصطناعي: نواةُ تجميع موجبة = مرشّح تمرير منخفض بلا تموّج.

مثال (6.50-7): معاملات σ_N

المعطيات: معاملات f: c_k. الحل: الخطوة 1: معاملات σ_N: $(1 - \frac{|k|}{N})c_k$ لـ$|k| < N$ وصفر بعدها. النتيجة: توهينٌ مثلّثي للتردّد العالي. الربط بالذكاء الاصطناعي: مرشّحٌ مثلّثي — أبسطُ مرشّح تنعيم في معالجة الإشارة.

مثال (6.50-8): فيير والضغط

المعطيات: نريد ضغطاً بلا آثار حواف. الحل: الخطوة 1: نستخدم توهيناً تدريجيّاً (مثل عامل فيير) بدل الاقتطاع الحادّ. الخطوة 2: الثمن: فقدانٌ طفيف في الحدّة. النتيجة: ضغطٌ أنظف بصريّاً. الربط بالذكاء الاصطناعي: مرشّحاتٌ ناعمة في الشبكات (Gaussian blur) تقلّل الآثار الاصطناعية.

مثال (6.50-9): متى نفضّل S_N على σ_N

المعطيات: دالةٌ ناعمة جدّاً. الحل: الخطوة 1: S_N أدقّ (يحتفظ بالمعاملات كاملة)؛ σ_N يوهنها. النتيجة: لا أفضلية مطلقة. الربط بالذكاء الاصطناعي: مفاضلة التحيز–التباين الكلاسيكية (الفصل 30).

مثال (6.50-10): فيير في تهيئة الشبكات

المعطيات: شبكةٌ بميزات فوريه عشوائية. الحل: الخطوة 1: التوهين المثلّثي يعادل توزيعاً احتماليّاً أوسع في التردّد $\Rightarrow$ استقرار. النتيجة: تهيئةٌ أفضل. الربط بالذكاء الاصطناعي: صلةٌ بتصميم ميزات فوريه العشوائية (RFF) في الفصل 54.

مثال (6.50-11): إثبات كمال النظام المثلثي بفيير

المعطيات: نريد أن نبرهن أن النظام كامل. الحل: الخطوة 1: $f \to \sigma_N$ موحّداً لكلّ متصلة، والمتصلات كثيفة في $L^2 \Rightarrow$ الكمال. النتيجة: برهانٌ أنيق بالتجميع. الربط بالذكاء الاصطناعي: حجج الكثافة هي نظيرُ «الشبكة تستطيع تقريب أيّ دالة» (الفصل 35).

مثال (6.50-12): أثر النواة على التسرّب

المعطيات: D_N له فصوص جانبية كبيرة. الحل: الخطوة 1: الفصوص تُسرّب الطاقة من التردّدات المجاورة (leakage). الخطوة 2: K_N فصوصها أصغر $\Rightarrow$ تسرّب أقل. النتيجة: النافذة تحدّد جودة التحليل (الفصل 51). الربط بالذكاء الاصطناعي: اختيارُ النافذة نظيرُ اختيار النواة في CNN.

مثال (6.50-13): قياس جودة التقريب

المعطيات: $\|f - S_N\|_\infty$ مقابل $\|f - \sigma_N\|_\infty$ لدالة فيها قفزة. الحل: الخطوة 1: الأول ≈ 179.0 ثابت، الثاني $\to 5.0$ (نصف القفزة) بلا تجاوز. النتيجة: فيير يقترب من القيمة «الصحيحة». الربط بالذكاء الاصطناعي: التقريب المستقرّ أقرب إلى الهدف وإن كان أنعم.

مثال (6.50-14): متوسطات سيزارو في التدريب

المعطيات: أوزانٌ تتذبذب بين الدفعات. الحل: الخطوة 1: متوسطُ الأوزان (EMA) يعطي حلاً أكثر استقراراً وتعميماً. الخطوة 2: التبرير الرياضي: نواة موجبة = توهين للتردّدات العالية في مسار التعلّم. النتيجة: تجميعٌ على طريقة فيير. الربط بالذكاء الاصطناعي: تفسيرُ نجاح SWA/EMA من زاوية التحليل الطيفي.

مثال (6.50-15): حدود فيير

المعطيات: نريد دقّةً قصوى لدالة ناعمة. الحل: الخطوة 1: فيير يوهن المعاملات $\Rightarrow$ يفقد دقّة يمكن تحصيلها. الخطوة 2: الحلول الوسطى (Lanczos، Kaiser) توازن بين النواتين. النتيجة: لا نواة مثالية لكلّ الأغراض. الربط بالذكاء الاصطناعي: اختيارُ الاستقراء (inductive bias) بحسب المهمة.

أخطاء شائعة

١. **الظنّ أن $\sigma_N = S_N$:** الأول متوسط المجاميع، وفيه توهين للمعاملات.

٢. **توقّع زوال التجاوز بزيادة N في S_N:** الحل هو تغيير النواة لا زيادة الحدود.

٣. **نسيان أن K_N ليست مجموعاً جزئياً:** هي نواة تجميع بمعاملات معدّلة.

٤. **استخدام فيير حيث النعومة عالية:** يخسر دقّة بلا مقابل.

٥. الخلط بين تقارب S_N النقطي وتقارب σ_N الموحّد: لكلٍّ شروطه.

تمهيد استفهامي

لماذا نكتب الجيب وتمام التمام في معاملين منفصلين، بينما يمكن أن نكتب كلّ توافقيّة **بمعاملٍ واحد**؟ الصيغة المركّبة c_k ليست ترفاً رمزيّاً: فهي التي تجعل الحساب جبريّاً بسيطاً (الإزاحة ضربٌ في e^{-ikx_0})، وهي التي تفتح الباب إلى DFT مباشرةً بلا وسيط، وهي التي توضح تماثلاً جميلاً: للإشارات الحقيقية، النصف السالب من الطيف هو **مرافق** النصف الموجب — أي أنّ نصف الطيف «مكرّر» ولا حاجة لتخزينه.

وهذا التكرار بالذات هو ما تستغلّه كلّ خوارزمية ضغط: نصفُ المعاملات معلوم من النصف الآخر.

صياغة رسمية

$$f(x)=\sum_{k=-\infty}^{\infty} c_k\, e^{ikx}, \qquad c_k=\frac{1}{2\pi}\int_{-\pi}^{\pi} f(x)e^{-ikx}\,dx \tag{1.7.50}$$

$$c_k=\frac{a_{|k|}-i\,b_{|k|}\,\mathrm{sgn}(k)}{2}\ (k\neq 0), \qquad c_0=\frac{a_0}{2} \tag{2.7.50}$$

$$f \text{ حقيقية} \implies c_{-k}=\overline{c_k} \quad \text{(تماثل هيرميتي)} \tag{3.7.50}$$

$$g(x)=f(x-x_0)\Rightarrow c_k(g)=e^{-ikx_0}c_k(f), \qquad |c_k(g)|=|c_k(f)| \tag{4.7.50}$$

إزاحة:

جدول الرموز

الرمز	المعنى	ملاحظة
c_k	المعامل المركّب	$k\in\mathbb{Z}$ (سالب وموجب)
e^{ikx}	الأسّ المركّب	$\cos kx+i\sin kx$
$\overline{c_k}$	المرافق المركّب	للتماثل
$\mathrm{sgn}(k)$	إشارة الفهرس	في التحويل بين الصيغتين
x_0	مقدار الإزاحة	يظهر كعامل طور

برهان (مخطط)

١. **(1.7.50)** من أويلر $e^{ikx}=\cos kx+i\sin kx$، والعموديّة $\frac{1}{2\pi}\int e^{ikx}e^{-imx}dx=\delta_{km}\Rightarrow$ الصيغة.

٢. **(2.7.50)** نجمع حدّي $\pm k$: $c_ke^{ikx}+c_{-k}e^{-ikx}=a_k\cos kx+b_k\sin kx\Rightarrow$ العلاقة بالمعاملات الحقيقية.

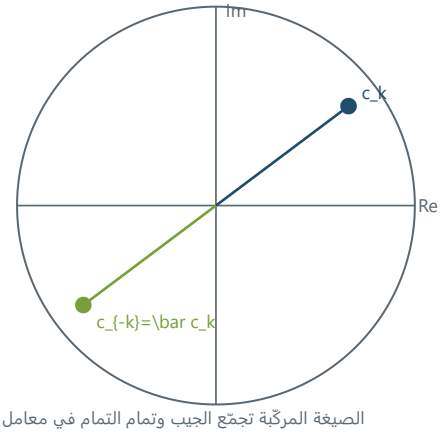
٣. **(3.7.50)** لأن $f=\bar f$: $c_{-k}=\frac{1}{2\pi}\int f\,e^{ikx}=\overline{c_k}$.

٤. **(4.7.50)** بالتعويض $u=x-x_0$ في التكامل. ■

شروط الصحّة: (3.7.50) للإشارات الحقيقية فقط. وفي الحساب المنفصل يصير التماثل دوريّاً: $X_{N-k}=\overline{X_k}$ (الفصل 51).

أمثلة محلولة (15)

فوريه المركّب: معاملات على دائرة الوحدة
Complex Fourier series coefficients



c_k=\frac{1}{2\pi}\int f e^{-ikx}
للدوالّ الحقيقية: تماثل هيرميتي

الصيغة المركّبة تجمّع الجيب وتمام التمام في معامل واحد — وتُفضي مباشرةً إلى

شكل ٦.٥٠: *
فوريه المركب: المعاملات على دائرة الوحدة والتماثل الهيرميتي للإشارات الحقيقية

مثال (50.7-1): من a_n, b_n إلى c_k

المعطيات: الموجة المربّعة $b_n = 4/(\pi n)$ للفرديّ n. الحل: الخطوة 1: $c_k = \frac{-i\, b_{|k|}\operatorname{sgn}(k)}{2} = -\frac{2i}{\pi k}$ للفرديّ k و0 للزوجي. النتيجة: معاملاتٌ تخيّلية صِرفة (لأن الدالة فرديّة). الربط بالذكاء الاصطناعي: فرديّة الإشارة ⇔ طيفٌ تخيّلي ⇔ طورٌ مقداره $\pi/2$.

مثال (50.7-2): تحقّق التماثل

المعطيات: $c_1 = -2i/\pi$. الحل: الخطوة 1: $c_{-1} = \overline{c_1} = +2i/\pi$ ✓. النتيجة: نصفُ الطيف يكفي. الربط بالذكاء الاصطناعي: توفيرٌ في التخزين والحساب بنسبة 50٪.

مثال (50.7-3): إزاحة في الزمن

المعطيات: نزيح الموجة المربّعة بمقدار $x_0 = \pi/4$. الحل: الخطوة 1: $c'_k = e^{-ik\pi/4} c_k$ ⇒ المطال ثابت والطور تغيّر. النتيجة: ثباتُ المطال للترجمة. الربط بالذكاء الاصطناعي: أساسُ مميّزات الصوت الثابتة للترجمة.

مثال (50.7-4): مطال وطور

المعطيات: $c_2 = 3 - 4i$. الحل: الخطوة 1: $|c_2| = 5$ والطور $\arg = -\arctan(4/3) \approx -53°$. النتيجة: تمثيلٌ بالمطال والطور أدنى إدراكيًّا. الربط بالذكاء الاصطناعي: الطور يحمل معلومات الموضع؛ وفقدانه مشكلة المُرمِّزات (الفصل 53).

مثال (7.50-5): دالة حقيقية زوجية

المعطيات: $f(x) = |x|$. الحل: الخطوة 1: $b_n = 0 \Rightarrow c_k = a_{|k|}/2$ حقيقي و$c_k = c_{-k}$. النتيجة: طيفٌ حقيقي ومتماثل. الربط بالذكاء الاصطناعي: الزوجيّة ⇒ طورٌ صفري ⇒ بلا إزاحة.

مثال (7.50-6): نغمة واحدة

المعطيات: $f(x) = \cos(3x)$. الحل: الخطوة 1: $c_3 = c_{-3} = 1/2$ والباقي صفر. النتيجة: معاملان فقط. الربط بالذكاء الاصطناعي: الطيف متناثر (sparse) — أساسُ الاستشعار الضاغط.

مثال (7.50-7): جمعُ إشارتين

المعطيات: $f = 2\cos x + 3\sin 2x$. الحل: الخطوة 1: $c_{\pm 1} = 1$ و$c_{\pm 2} = \mp\frac{3i}{2}$. النتيجة: خطّية التحويل تجعل التركيب سهلاً. الربط بالذكاء الاصطناعي: التراكب (superposition) — سببُ قوة التحليل الطيفي.

مثال (7.50-8): الالتفاف يصير ضرباً

المعطيات: h مرشّح بمعاملات h_k، وf إشارة. الحل: الخطوة 1: معاملات $f * h$: $2\pi\, h_k c_k$ (ضرب). النتيجة: الترشيح في مجال فوريه ضربٌ لا التفاف. الربط بالذكاء الاصطناعي: مبرهنة الالتفاف (الفصل 51) تبدأ من هنا.

مثال (7.50-9): مشتقة الإشارة

المعطيات: معاملات f' من معاملات f. الحل: الخطوة 1: $c_k(f') = ik\, c_k(f) \Rightarrow$ المشتقة تضخّم التردّد العالي بـk. النتيجة: التفاضل يُبرز التفاصيل ويُضخّم الضجيج. الربط بالذكاء الاصطناعي: سببُ أنّ losses في مجال التدرّج (gradient domain) حسّاسة للضجيج.

مثال (7.50-10): تكامل الإشارة

المعطيات: معاملات $\int f$. الحل: الخطوة 1: $c_k/k \Rightarrow$ التكامل يُخفض التردّد العالي (تنعيم). النتيجة: التكامل مرشّح تمرير منخفض. الربط بالذكاء الاصطناعي: التجميع/التجميع التراكمي في السلاسل الزمنية أثرُه تنعيمي.

مثال (7.50-11): طاقة بالصيغة المركّبة

المعطيات: $c_k = -2i/(\pi k)$ للفرديّ. الحل: الخطوة 1: $\cdot\ \frac{8}{\pi^2} = 2\sum_{k>0,\text{فردي}} \frac{4}{\pi^2 k^2}$ $\sum_k |c_k|^2 = 1 = \frac{\pi^2}{8}$ ✓. النتيجة: بارسيفال بالصيغة المركّبة (2.5.50). الربط بالذكاء الاصطناعي: صيغةٌ واحدة للحساب في كلّ صور فوريه.

مثال (12-7.50): تماثل في الحالة المنفصلة

المعطيات: $N = 8$ عيّنة حقيقية. الحل: الخطوة 1: $X_{N-k} = \overline{X_k} \Rightarrow$ نخزّن $N/2 + 1$ معاملاً. النتيجة: توفيرٌ بتناظر الطيف. الربط بالذكاء الاصطناعي: مكتبات FFT (rfft) تعتمد هذا التناظر.

مثال (13-7.50): إشارة مركّبة (تحليل المغلف)

المعطيات: إشارة تحليلية (analytic signal) بطيفٍ للموجب فقط. الحل: الخطوة 1: نلغي الترددات السالبة ونضاعف الموجبة ⇒ إشارة مركّبة. الخطوة 2: مقدارُها = المغلف (envelope)، وطورُها = الطور الآني.

النتيجة: استخراج المغلف والطور. الربط بالذكاء الاصطناعي: تحويل هيلبرت خطوةٌ أساسية في تحليل الاهتزازات والصوت.

مثال (14-7.50): دور الطور في الإدراك

المعطيات: طيفان بمطالٍ متساوية وأطوار مختلفة. الحل: الخطوة 1: الصوت يتغيّر جذريّاً، والصورة تُعاد ترتيبها بصريّاً. النتيجة: الطور ليس تفصيلاً ثانويّاً. الربط بالذكاء الاصطناعي: مشكلةُ إعادة بناء الطور في المُرمِّزات العصبية (الفصل 53).

مثال (15-7.50): من المتصل إلى المنفصل

المعطيات: N عيّنة من إشارة دورية. الحل: الخطوة 1: $c_k \approx \frac{1}{N}\sum_n f_n e^{-2\pi i k n/N} \Rightarrow$ هذا هو DFT. النتيجة: الجسر إلى الفصل 51. الربط بالذكاء الاصطناعي: كلّ تحليلٍ طيفي في الحاسوب يبدأ من هذه الصيغة.

أخطاء شائعة

١. **نسيان أن $c_0 = a_0/2$:** لا a_0.

٢. **تجاهل التماثل الهيرميتي وتخزين الطيف كاملاً:** هدرٌ بنسبة 50٪.

٣. **الخلط بين الإزاحة في الزمن والطور:** الأول يغيّر الطور خطّياً في k.

٤. **اعتبار الطور غير مهم:** هو حامل موضع البنية المكانية.

٥. **استخدام صيغة المتصل في بيانات منفصلة بلا تحقّق:** ينتج عنه تسريب (الفصل 51).

تمهيد استفهامي

لديك ميزانية: عشرون معاملاً لا أكثر. أيّ عشرين تختار؟

- الخيار الأول: أول عشرين توافقيّة ($|k| \le 20$).

- الخيار الثاني: أكبر عشرين معاملاً بالمقدار، أيّاً كان موضعها.

أيّهما أفضل؟ الجواب — بفضل بارسيفال (4.5.50) — أنّ **الثاني أفضل دائماً** (أو مساوٍ): خطأ الاقتطاع هو بالضبط طاقةُ الذيل، وتقليلُه يكون بحذف أصغر المعاملات لا آخرها. هذه حقيقةٌ بسيطة لكنّها قلبُ كلّ ضغط: JPEG وMP3 وتقليم الشبكات (pruning) وتقليل الرتبة (LoRA) كلّها تطبيقات لخيارٍ واحد: **احذف الأصغر، واحسب الخسارة من مربّعاته.**

صياغة رسمية

$$P_N f = \sum_{|k|\le N} c_k e^{ikx} \qquad \text{معاملاً في القاعدة المثلثية: } N \text{ أفضل تقريب بـ} \tag{1.8.50}$$

$$\min_{\Lambda} \|f - \sum_{k\in\Lambda} c_k e^{ikx}\|^2 = \sum_{k\notin\Lambda^\star} |c_k|^2 \qquad \text{لكن الأمثل على أيّ مجموعة معاملات } \Lambda,\ |\Lambda| = N : \tag{2.8.50}$$

$$\Lambda^\star = \text{أكبر } N \text{ معاملات بالمقدار (قاعدة الاختيار النهم greedy)} \tag{3.8.50}$$

$$|c_k| = O(k^{-(m+1)}) \text{ قطعيّاً لدالة } C^m \text{ ومعدّل اضمحلال الذيل يحكم الدقّة:} \tag{4.8.50}$$

جدول الرموز

الرمز	المعنى	ملاحظة
P_N	الإسقاط على أول N	تقريب «الاقتطاع المتوالي»
Λ	مجموعة معاملات مختارة	N = cardinality
$\Lambda^\star$	المجموعة المثلى	أكبر المعاملات
m	رتبة النعومة	تحدّد سرعة الاضمحلال
$O(k^{-(m+1)})$	معدّل الذيل	أُسّيّ للدوالّ التحليلية

برهان (مخطط)

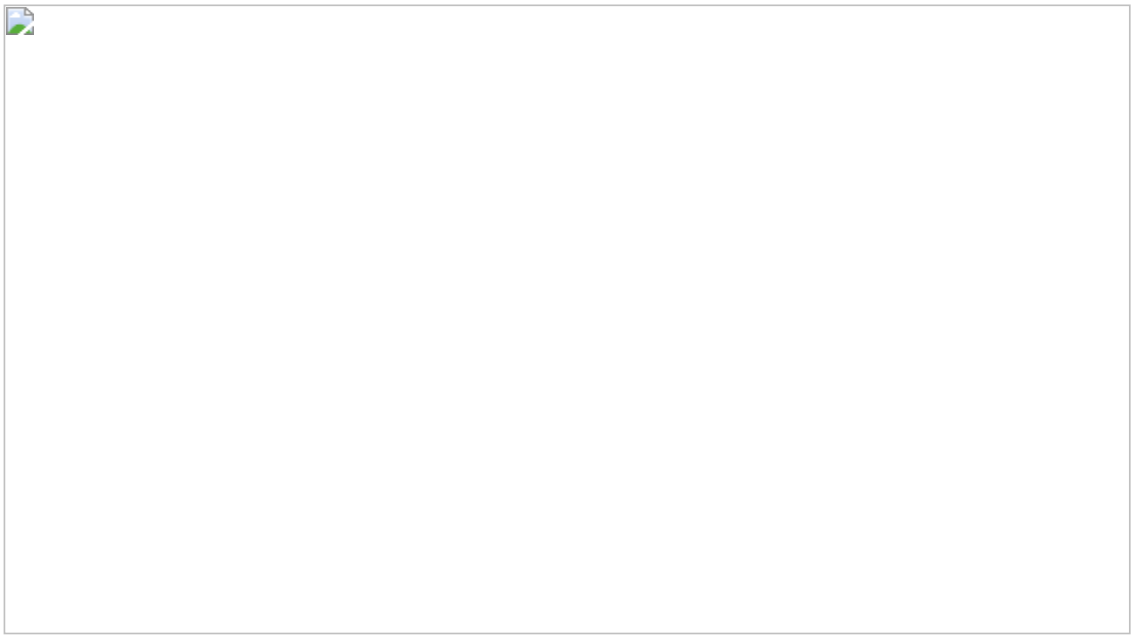
١. **(1.8.50)** من (3.8.49): أفضل تقريب في فضاء جزئي = الإسقاط العمودي.

٢. **(2.8.50–3.8.50)** الخطأ $2\pi\sum_{k\notin\Lambda}|c_k|^2$ = بارسيفال؛ وتقليل مجموعٍ بمجموعةٍ ذات حجم ثابت يتحقّق بأخذ أكبر الحدود (حجّة تبادلية: إن كان $k_1\in\Lambda$ و$k_2\notin\Lambda$ مع $|c_{k_2}|>|c_{k_1}|$ فالتبديل يخفض الخطأ).

٣. **(4.8.50)** بالتكامل بالتجزئة المتكرّر على معامل c_k: كلّ مشتقةٍ متصلة تعطي عاملاً $1/k$ إضافيّاً، وللدوالّ التحليلية يمتدّ التحليل إلى شريط مركّب $\Rightarrow$ اضمحلال أُسّيّ. ■

شروط الصحّة: (3.8.50) يعطي الأمثل في قاعدة **ثابتة**؛ أمّا اختيارُ قاعدةٍ أفضل للمهمة فمسألة أخرى (المويجات للقفزات — الفصل 52). والذيل في (4.8.50) تقديرٌ مقارِب لا حدّاً محكماً دائماً.

أمثلة محلولة (15)



شكل ٧.٥٠: *
من الدالة إلى معاملات فوريه ثم إعادة التركيب بعد الاقتطاع

مثال (8.50-1): اقتطاع متوالٍ مقابل اختيار نهم

المعطيات: معاملات $|c_k|$: $0.9 = |c_1| > |c_2| = 0.01 > |c_{50}|$. الحل: الخطوة 1: الاقتطاع المتوالي بـ $N = 2$ يعطي خطأً $0.9^2 + 0.01^2 \approx 0.81 =$. الخطوة 2: الاختيار النهم يأخذ $\{c_1, c_{50}\} \Rightarrow$ خطأ $= 0.01^2 = 10^{-4}$. النتيجة: فرقٌ هائل — الموضع أهمّ من الترتيب. الربط بالذكاء الاصطناعي: تقليمُ الأوزان بالمقدار (magnitude pruning) لا بالموضع.

مثال (8.50-2): ذيل $1/k$ لدالة فيها قفزة

المعطيات: الموجة المربّعة، $N = 100$. الحل: الخطوة 1: الخطأ $\sum_{k>100} 1/k^2 \approx 1/100 \Rightarrow$ الخطأ $^2 \propto$ الخطأ ≈ 0.1. النتيجة: تقاربٌ بطيء جدّاً. الربط بالذكاء الاصطناعي: الدوالّ المتقطّعة مكلفةٌ طيفيّاً $\Rightarrow$ المويجات أفضل لها.

مثال (8.50-3): ذيل $1/k^2$ للدوالّ المتصلة

المعطيات: الموجة المثلثية، $N = 10$. الحل: الخطوة 1: الخطأ $\sum_{k>10} 1/k^4 \approx 1/(3 \cdot 10^3) \Rightarrow$ خطأ $^2 \propto$ خطأ ≈ 0.018. النتيجة: دقّةٌ ممتازة بعشرة معاملات. الربط بالذكاء الاصطناعي: نعومةُ الهدف تُترجَم سعةً أقلّ للنموذج.

مثال (8.50-4): دالة تحليلية $\Rightarrow$ ذيل أُسّيّ

المعطيات: $f(x) = e^{\cos x}$. الحل: الخطوة 1: معاملاتها دوالّ بيسل معدّلة؛ وتضمحل أُسّيّاً في k. النتيجة: عشراتُ

المعاملات تعطي دقّة الآلة. الربط بالذكاء الاصطناعي: الطيف «المتناثر جدّاً» سببُ نجاح الضغط الشديد.

مثال (8.50-5): ميزانية دقّة

المعطيات: نريد $\|f - S_N\| < 0.01$ لدالة C^1 (ذيل $1/k^2$). الحل: الخطوة 1: $\sum_{k>N} 1/k^4 \approx \frac{1}{3N^3} < 10^{-4} \Rightarrow N \approx 15$. النتيجة: 15 معاملاً تكفي. الربط بالذكاء الاصطناعي: تحديد سعة النموذج من ذيل الطيف قبل التدريب.

مثال (8.50-6): مفاضلة السعة مقابل الدقّة

المعطيات: مضاعفة N للدالة ذات ذيل $1/k^2$. الحل: الخطوة 1: الخطأ يتناقص بعامل $2^{3/2} \approx 2.83$ في المعيار L^2. النتيجة: عائدٌ متناقص. الربط بالذكاء الاصطناعي: منحنى «الدقّة مقابل الحجم» في النماذج هو هذا الذيل.

مثال (8.50-7): اختيار القاعدة

المعطيات: إشارةٌ فيها قفزة واحدة. الحل: الخطوة 1: فوريه يوزّع أثر القفزة على كلّ k؛ والمويجات تحصره في قليل من المعاملات. النتيجة: القاعدة المناسبة توفر أضعافاً. الربط بالذكاء الاصطناعي: الاستقراء (inductive bias) يبدأ من اختيار التمثيل.

مثال (8.50-8): ضغط صورة باقتطاع DCT

المعطيات: كتلة 8×8 بمعاملات DCT. الحل: الخطوة 1: نحذف المعاملات عالية التردّد تحت عتبة $\Rightarrow$ خطأ = طاقة المحذوف. الخطوة 2: تكميمٌ إضافي يحذف دقّة التخزين. النتيجة: ضغط JPEG خطوةً بخطوة. الربط بالذكاء الاصطناعي: كلّ ضغطٍ بالمكوّنات يتبع (2.8.50) حرفيّاً.

مثال (8.50-9): تقريب شبكة بميزات فوريه

المعطيات: نموذجٌ بميزات عشوائية فوريه. الحل: الخطوة 1: عدد الميزات D يحدّد عرض النطاق المُمثَّل $\Rightarrow$ خطأ اقتطاع $\sim$ ذيل الطيف. النتيجة: اختيار D من طيف الهدف. الربط بالذكاء الاصطناعي: تصميمُ RFF وSIREN (الفصل 54).

مثال (8.50-10): خطأ الاقتطاع في FNO

المعطيات: مؤثّرٌ عصبي يحفظ K أوضاعاً. الحل: الخطوة 1: خطأ الاقتطاع = طاقة الأوضاع فوق K في حقول الحلّ. الخطوة 2: إن كانت الحلول ناعمة، فـK صغير يكفي. النتيجة: كفاءة FNO مرتبطة بنعومة حلول المعادلة. الربط بالذكاء الاصطناعي: مبرّرُ نجاح الطرائق الطيفية في المعادلات التفاضلية.

مثال (11-8.50): مقارنة معايير

المعطيات: خطأ بمعايير L^2 وL^∞ للدالة نفسها. الحل: الخطوة 1: L^2 يزول كـ$N^{-1/2}$ وL^∞ ثابت (غيبس) عند القفزة. النتيجة: المعيار يحدّد الحكم. الربط بالذكاء الاصطناعي: اختيارُ دالة الفقد = اختيارُ المعيار.

مثال (12-8.50): تقريب أفضل من الاقتطاع المتوالي

المعطيات: طيفٌ متناثر: 5 معاملات كبيرة عند تردّدات عشوائية. الحل: الخطوة 1: الاقتطاع المتوالي يحتاج $N \sim$ أعلى تردّد، والاختيار النهم يحتاج 5 فقط. النتيجة: توفيرٌ بأضعاف. الربط بالذكاء الاصطناعي: الاستشعار الضاغط (compressed sensing) تطبيقه الأشهر.

مثال (13-8.50): النعومة من الطيف والعكس

المعطيات: طيفٌ بذيل $1/k^4$. الحل: الخطوة 1: بـ(4.8.50): الذيل $k^{-4} = k^{-(m+1)} \Rightarrow m = 3 \Rightarrow$ الدالة C^3 تقريباً. النتيجة: قراءةُ نعومة الدالة من طيفها. الربط بالذكاء الاصطناعي: تشخيصُ نعومة البيانات من طيف التدرّجات.

مثال (14-8.50): حساب تكلفة تقييم التقريب

المعطيات: N معاملات، وM نقطة تقييم. الحل: الخطوة 1: التقييم المباشر $O(MN)$؛ وعبر FFT $O(M \log M + N \log N)$. النتيجة: FFT أرخص للقيم الكبيرة. الربط بالذكاء الاصطناعي: مبرّرُ حساب الالتفاف في مجال التردّد (الفصل 51).

مثال (15-8.50): الضغط بلا فقدان محسوس

المعطيات: نحذف المعاملات التي طاقتها $< 1\%$ من الكلّ. الحل: الخطوة 1: بـ(4.5.50): الخطأ $< 1\%$ من الطاقة $\Rightarrow$ عادةً غير محسوس إدراكيّاً. النتيجة: ضغطٌ مدفوعٌ بميزانية خطأ معلنة. الربط بالذكاء الاصطناعي: معيارُ «الجودة المقبولة» يُترجَم ميزانية طاقة.

أخطاء شائعة

١. **الظنّ أن أول N توافقيّة هي الأمثل:** الأمثل أكبرُ N معاملاً (3.8.50).

٢. **تجاهل معدّل الذيل عند تحديد الميزانية:** ينتج عنه نقصٌ أو هدر في السعة.

٣. **استخدام فوريه للإشارات المتقطّعة بلا تفكير:** المويجات أصلح.

٤. **الخلط بين خطأ L^2 والنقطي عند القفزات:** الأول يزول والثاني لا.

٥. **اعتبار الاقتطاع «الخيار الوحيد»:** العتبة الناعمة (soft-thresholding) غالباً أفضل (الفصل 52).

تمارين (30)

مستوى أول:

١. احسب معاملات فورييه لـ $f(x) = x^2$ على $[-\pi, \pi]$.

٢. احسب معاملات النبضة المستطيلة بعرض $\tau = \pi/2$.

٣. بيّن أن $b_n = 0$ لكلّ دالة زوجية.

٤. اوجد متسلسلة فورييه لـ $f(x) = |\sin x|$.

٥. احسب $c_{\pm 2}$ لدالة $\cos 2x + 3\sin 2x$.

٦. تحقّق من بارسيفال للموجة المثلثية.

٧. احسب الطاقة في أول 3 توافقيّات للموجة المربّية.

٨. اكتب $K_2(t)$ صراحةً وتحقّق من أنها ≥ 0.

٩. احسب σ_2 للموجة المربّية.

١٠. اوجد معاملات $f(x) = e^x$ على $[-\pi, \pi]$ (مبدئيّاً).

مستوى ثان:

١. اشتقّ صيغة $D_N(t)$ من مجموع المتسلسلة الهندسية للأسّيات.

٢. برهن أن $\int |D_N| \sim \frac{4}{\pi} \ln N$ (مخطط).

٣. برهن (2.6.50): متوسط نوى ديريكلِه يعطي المربع الموجب.

٤. اربط بين ذيل الطيف $1/k^2$ واتصال الدالة (استخدم التكامل بالتجزئة).

٥. بيّن أن $|c_k| = O(k^{-(m+1)})$ لدالة C^m قطعيّاً.

٦. احسب خطأ اقتطاع L^2 لسنّ المنشار بـ $N = 50$.

٧. قارن خطأ الاقتطاع المتوالي بالاختيار النهم لطيفٍ متناثر.

٨. برهن (4.7.50) لخاصية الإزاحة.

٩. اشرح لماذا لا يتناقص تجاوز غيبس مع N (بصيغة Si).

١٠. اربط بين نواة فيير والتوهين المثلّثي للمعاملات.

مستوى ثالث:

١. صورةٌ فيها حوافّ حادّة: صف أثر غيبس واقترح علاجين.

٢. شبكةٌ تتعلّم دالة مربّعية: توقّع ترتيب تعلّم التردّدات وعلّل.

٣. ضغط صوت: احسب نسبة الضغط عند حذف المعاملات التي $|c_k| < 0.01 \max$.

٤. لماذا تُفضَّل الموجات على فوريه للإشارات المتقطّعة؟ (مخطط رياضي)

٥. صغ مسألة اختيار سعة النموذج بوصفها مسألة اقتطاع طيفي.

٦. اشرح كيف يجعل التماثل الهيرميتي الضغط أوفر بنسبة ٥٠٪.

٧. قارن بين توهين فيير وعامل لانچوس من حيث الفصوص الجانبية.

٨. اربط بين متوسطات الأوزان (EMA) ونواة فيير في مسار التعلّم.

٩. كيف تكتشف من الطيف أن البيانات ناعمة أم متقطّعة؟

١٠. صمّم تجربةً عددية تتحقّق من ثابت غيبس 8.95% بدقّة 10^{-3}.

ملخص الفصل

النظرية	الصيغة المحوريّة	الدرس العملي
المعاملات والعموديّة	a_n, b_n إسقاطات على قاعدة عمودية	المعامل = «كم من هذه النغمة»
تقارب ديريكلِه	استمرار $f \Rightarrow$، قفزة $\Rightarrow$ نصف المجموع	نقطةٌ واحدة لا تغيّر الطيف
ظاهرة غيبس	تجاوز $8.95\% \approx$ دائم	زيادة الحدود تضيّق الخطأ لا تصغّره
بارسيفال	$\frac{1}{2\pi}\int \|f\|^2 = \sum \|c_k\|^2$	الطاقة محفوظة $\Rightarrow$ الضغط ممكن
نواتا ديريكلِه وفيير	D_N متذبذبة، K_N موجبة	بدّل التجميع قبل زيادة الحدود
فوريه المُركّب	c_k، $c_{-k} = \overline{c_k}$	نصف الطيف يكفي للحقيقية
التقريب الأمثل	احذف أصغر المعاملات	الخطأ = طاقة الذيل بالضبط

الجسر إلى الفصل 51: كلّ ما هنا كان للإشارات **الدوريّة** (طيفٌ متقطّع). فماذا عن إشارةٍ غير دورية — كلمةٌ منطوقة، أو صورة، أو زمنٌ مفتوح؟ يحتاج الأمر إلى **تحويل فوريه** بمعناه المتّصل: طيفٌ مستمرّ، وصيغتان متقابلتان، ونظريةٌ للعيّنات تحدّد متى تكفي العيّنات لتمثيل الإشارة كلها.

جدول الرموز (فهرس الفصل)

الرمز	المعنى
a_n, b_n, c_k	معاملات فوريه (حقيقية ومركّبة)
S_N, σ_N	المجموع الجزئيّ ومجموع فيير
D_N, K_N	نواتا ديريكلِه وفيير
J	سعة القفزة
$\mathrm{Si}(\pi)$	تكامل الجيب ≈ 1.8519
$\|\cdot\|_{L^2}, \|\cdot\|_\infty$	معيارا الطاقة والأسوأ
$\Lambda^\star$	مجموعة المعاملات المثلى للاقتطاع

نهاية الفصل الخمسين — ومنه نعبر إلى تحويل فوريه ونظرية العيّنات في الفصل الحادي والخمسين.

تحويل فوريه، العيّنات، ونظرية نيكويست–شانون

الشعار: «الزمنُ والتردّدُ لغتان لشيءٍ واحد؛ والعيّنةُ الصادقةُ هي التي تحمل اللغتين معاً.»

تمهيد قصصي للفصل: كم صورةً في الثانية؟

في أواخر العشرينيات من القرن الماضي، كان المهندسون في مختبرات بيل يسألون سؤالاً عملياً بحتاً: **كم مرّةً يجب أن نقيس الإشارة كي نستطيع إعادة بنائها لاحقاً بلا فقدان؟** القياس مكلف (تخزين، إرسال، طاقة)، والزيادة فيه هدر، والنقصان فيه كارثة: إشارةٌ مشوّهة لا تُصلح.

وجاء الجواب في صيغةٍ مذهلة في بساطتها: **مرّتان عرض نطاقها** — لا أكثر. هذا هو شرط نيكويست، ونظرية شانون للعيّنات تكمله بوصفة إعادة البناء: interpolate بـsinc. ولولا هذه النظرية لما وُجد الهاتف الرقمي، ولا الصوت على القرص المضغوط (1.44 ،kHz) ولا التصوير الرقمي، ولا واجهات اللمس، ولا موجات الرادار.

لكنّ النظرية تحمل تحذيراً مرعباً في ثناياها: إن خالفت الشرط، **تتحوّل الترددات العالية إلى ترددات منخفضة كاذبة** (aliasing) — ترى ما ليس موجوداً، ولا سبيل إلى تراجع. وفي التعلّم العميق يقابلها: عيّناتُ تدريبٍ قليلة عن ظاهرةٍ سريعة تعطي نموذجاً واثقاً من وهمٍ محض.

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. حساب **تحويل فوريه المتّصل** واستخدام خصائصه (خطّية، إزاحة، تحجيم، التفاف↔ضرب).

٢. تعريف **DTFT** و**DFT** وحساب تعقيد **FFT** ومعرفة متى يتفوّق على الالتفاف المباشر.

٣. تطبيق **نظرية نيكويست–شانون** لتحديد معدّل العيّنات وإعادة البناء بـsinc.

٤. تشخيص **التشويه الطيفي** (aliasing) ومكافحته بمرشّح مضادّ.

٥. استخدام **مبرهنة الالتفاف** في الترشيح، وفهم **التسرّب الطيفي** واختيار النوافذ.

٦. حساب **طيف القدرة** وربطه بالارتباط الذاتي (فينر–خينتشين).

٧. توظيف الطيف في التعلّم العميق (التحيّز الطيفي، الالتفاف بـFFT، الطبقات الطيفية).

المتطلبات المسبقة

الفصلان 49 و50، والفصل 10 (التكامل)، والفصل 4 (القيم الذاتية).

خريطة الفصل

القسم	القانون/النظرية	عدد الأمثلة المحلولة
1.51	من المتسلسلة إلى التحويل: المفردات	—
2.51	**تحويل فوريه المتّصل وخصائصه**	15
3.51	**DTFT وDFT وخوارزمية FFT**	15
4.51	**نظرية العيّنات نيكويست–شانون**	15
5.51	**التشويه الطيفي (Aliasing) ومكافحته**	15
6.51	**مبرهنة الالتفاف والنوافذ والتسرّب**	15
7.51	**طيف القدرة وفينر–خينتشين**	15
8.51	**الطيف في التعلّم العميق**	15
9.51	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

Convolution · Butterfly · FFT · DFT · DTFT · Transform Inverse · Transform Fourier Interpolation Sinc · Filter Anti-alias · Aliasing · Rate Nyquist · Theorem Sampling · Theorem · Spectrogram · Wiener–Khinchin · Density Spectral Power · Leakage Spectral · Windowing · Bias Spectral

حين يطول الدور ($T \to \infty$) تصير التوافقيّات متقاربة، فيتحوّل الطيف من **متقطّع** (معاملات c_k) إلى **متّصل** (دالة $X(\omega)$):

$$f(x) = \sum_{k} c_k e^{ikx} \quad \longrightarrow \quad x(t) = \frac{1}{2\pi}\int X(\omega) e^{i\omega t}\, d\omega \tag{1.1.51}$$

دوريّة: غير دوريّة:

الرمز	المعنى	ملاحظة
ω	التردّد الزاوي (rad/s)	$\omega = 2\pi f$ وf بالهرتز
$X(\omega)$	طيف الإشارة	مركّب: مطال وطور
$T_s,\ f_s$	زمن العيّنة ومعدّلها	$f_s = 1/T_s$
B	عرض النطاق (bandwidth)	أعلى تردّد موجود
N	طول الإطار المنفصل	يحدّد دقّة التردّد
sinc	نواة إعادة البناء	$\sin(\pi t)/(\pi t)$

الرابط بالفصل السابق: (1.1.51) هو مرورٌ بالنهاية من متسلسلة إلى تكامل — تماماً كما مررنا في (49.x) من المجاميع إلى التكاملات في المعيار التكاملي.

تمهيد استفهامي

إشارةٌ غير دورية — كلمةٌ منطوقة مرةً واحدة. ما «ترددّاتها»؟ ليس للكلمة تردّدٌ أساسي واحد، بل **حزمةٌ متّصلة** من الترددّات لكلّ لحظة. فكيف نحسبها؟

تحويل فوريه يجيب: نُبدل الجمع بالتكامل، فتصير كلّ ترددّيةٍ «كميةً صغيرة» من الإشارة. والقوّة هنا ليست في التعريف بل في **الخصائص**: فالالتفاف (أثقل عملية في معالجة الإشارة) يصير ضرباً، والإزاحة تصير طوراً، والتفاضل يصير جداءً بـ$i\omega$. هذه الخصائص هي التي تجعل التحويل أداةً لا تعريفاً.

صياغة رسمية

$$X(\omega) = \int_{-\infty}^{\infty} x(t)\, e^{-i\omega t}\, dt, \qquad x(t) = \frac{1}{2\pi}\int_{-\infty}^{\infty} X(\omega)\, e^{i\omega t}\, d\omega \tag{1.2.51}$$

$$\mathcal{F}\{ax+by\} = aX + bY \quad \text{:خطّية} \tag{2.2.51}$$

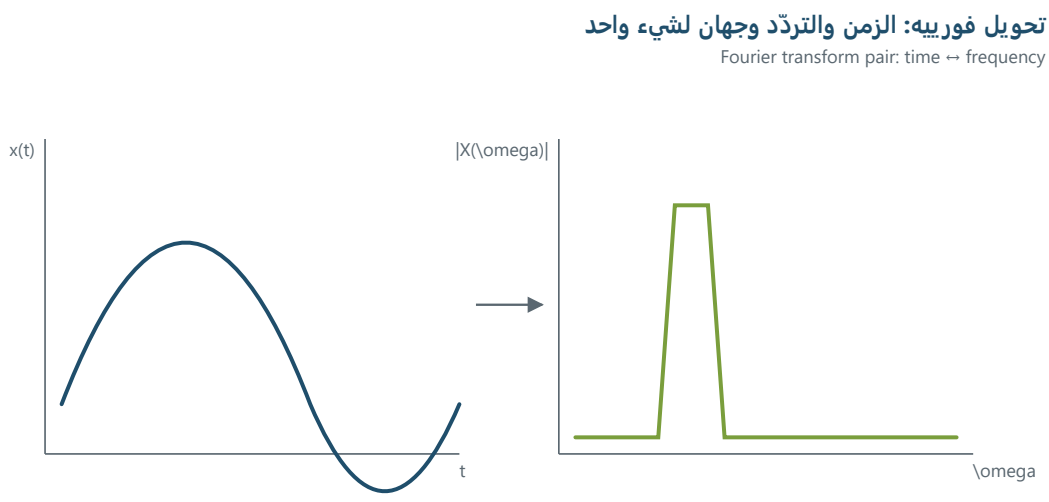
$$\mathcal{F}\{x(at)\} = \frac{1}{|a|}X(\omega/a) \quad \text{:تحجيم} \qquad \mathcal{F}\{x(t-t_0)\} = e^{-i\omega t_0}X(\omega), \quad \text{:إزاحة} \tag{3.2.51}$$

$$\mathcal{F}\Big\{\int_{-\infty}^{t} x\Big\} = \frac{X(\omega)}{i\omega} + \pi X(0)\delta(\omega) \quad \text{:تكامل} \qquad \mathcal{F}\{x'\} = i\omega X(\omega), \quad \text{:تفاضل} \tag{4.2.51}$$

$$\mathcal{F}\{x(t)e^{i\omega_0 t}\} = X(\omega-\omega_0) \quad \text{:تعديل} \tag{5.2.51}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$X(\omega)$	الطيف (مطال وطور)	مركّب
t_0	إزاحة زمنية	تظهر كعامل طور خطّي
a	معامل التحجيم	الضيق في الزمن = الانتشار في التردّد
ω_0	تردّد التعديل (ناقلة)	أساس الراديو والاتصالات
δ	دالة ديراك	للتردّد الصفري والمكوّنات النقيّة



شكل ١٠٥١: *
تحويل فورييه المتصل: الإشارة في الزمن وطيفها في التردد

برهان (مخطط)

١. **(1.2.51)** نبدأ من متسلسلة فورييه لدور T، ونقسّم على التباعد الطيفي $\Delta\omega = 2\pi/T$، ونمرّر بـ $T \to \infty$، فيصير المجموع تكاملاً (مجموع ريمان).

٢. **(3.2.51)** بالتعويض المباشر $u = t - t_0$ و $u = at$.

٣. **(4.2.51)** بالتجزئة على $x' e^{-i\omega t}$ مع افتراض اضمحلال الحدود.

٤. **(5.2.51)** من الخاصية الأساسية للأسّيات: جداء في الزمن = إزاحة في التردّد. ■

شروط الصحّة: وجود التحويل يحتاج $x \in L^1$ (أو L^2 بمعنى النواظم/توزيعات للإشارات كالخطوة والنبضة). ودالة ديراك في (4.2.51) تظهر بوصفها توزيعاً — لا دالة عادية.

أمثلة محلولة (15)

مثال (1-2.51): النبضة المستطيلة

المعطيات: $x(t) = 1$ على $|t| \le \tau/2$. الحل: الخطوة 1: $X(\omega) = \int_{-\tau/2}^{\tau/2} e^{-i\omega t} dt = \frac{2\sin(\omega\tau/2)}{\omega} = \tau\,\mathrm{sinc}(\omega\tau/2)$. النتيجة: طيفٌ من نمط sinc بأصفار عند $\omega = 2\pi k/\tau$. الربط بالذكاء الاصطناعي: أوسعُ نبضة في الزمن $\Rightarrow$ أضيقُ طيف (مبدأ الريبة).

مثال (2-2.51): الأُسّي المتضائل

المعطيات: $x(t) = e^{-at}u(t)$، $a > 0$. الحل: الخطوة 1: $X(\omega) = \int_0^\infty e^{-(a+i\omega)t} dt = \frac{1}{a+i\omega}$. الخطوة 2: المطال $1/\sqrt{a^2+\omega^2}$ والطور $-\arctan(\omega/a)$. النتيجة: طيفٌ منخفض التمرير «لورنتزي». الربط بالذكاء الاصطناعي: استجابةُ أنظمة الدرجة الأولى (RC، SGD) والزخم في .

مثال (3-2.51): الغاوسي ثابتٌ تحت التحويل

المعطيات: $x(t) = e^{-t^2/2\sigma^2}$. الحل: الخطوة 1: $X(\omega) = \sigma\sqrt{2\pi}\, e^{-\sigma^2\omega^2/2}$ — غاوسي أيضاً. النتيجة: الغاوسي يحقّق حدّ مبدأ الريبة بصرامة. الربط بالذكاء الاصطناعي: نواةُ غاوس في المرشّحات والطبقات هي الأمثل زمنيّاً-ترددّيّاً.

مثال (4-2.51): دالة ديراك والخطوة

المعطيات: $x(t) = \delta(t)$ ثم $x(t) = u(t)$. الحل: الخطوة 1: $\mathcal{F}\{\delta\} = 1$ (طيفٌ ثابت = كلّ الترددّات). الخطوة 2: $\mathcal{F}\{u\} = \pi\delta(\omega) + \frac{1}{i\omega}$ (بمعنى التوزيعات). النتيجة: النبضة المثالية تحمل كلّ الترددّات بالتساوي. الربط بالذكاء الاصطناعي: الالتفاف بنواة دلتا = الهوية؛ ومنه «التفاف 1×1» مزجٌ للقنوات.

مثال (5-2.51): طيف الجيب النقي

المعطيات: $x(t) = \cos(\omega_0 t)$. الحل: الخطوة 1: $X(\omega) = \pi[\delta(\omega-\omega_0) + \delta(\omega+\omega_0)]$. النتيجة: نبضتان في الطيف. الربط بالذكاء الاصطناعي: الترميز الموضعي الجيبي في المحوّلات يستخدم أطيافاً من هذا النوع.

مثال (51.2-6): خاصية الإزاحة

المعطيات: $x(t-t_0)$ بمقدار $t_0=3$ ثوانٍ. الحل: الخطوة 1: $X'(\omega)=e^{-3i\omega}X(\omega)\Rightarrow$ المطال ثابت والطور -3ω. النتيجة: تأخيرٌ زمني طورٌ خطّي. الربط بالذكاء الاصطناعي: مميّزات الصوت ثابتة للإزاحة لأن المطال لا يتغيّر.

مثال (51.2-7): التفاضل يضخّم العالي

المعطيات: $x'(t)$ لإشارة ناعمة. الحل: الخطوة 1: $|\mathcal{F}\{x'\}| = |\omega|\,|X(\omega)|\Rightarrow$ تضخيمٌ خطّي للتردّد العالي. النتيجة: التفاضل يكشف الحواف ويضخّم الضجيج معاً. الربط بالذكاء الاصطناعي: losses في مجال التدرّج حسّاسة للضجيج لهذا السبب.

مثال (51.2-8): التعديل (نقل الطيف)

المعطيات: $x(t)\cos(\omega_c t)$. الحل: الخطوة 1: الطيف $=\frac{1}{2}[X(\omega-\omega_c)+X(\omega+\omega_c)]$. النتيجة: نسخٌ من الطيف حول الناقلة $\pm\omega_c$. الربط بالذكاء الاصطناعي: التضمين في الاتصالات، و«FiLM» تعديلٌ تعلّمي في الشبكات.

مثال (51.2-9): التحجيم والمفاضلة

المعطيات: ضغط الإشارة زمنيّاً بعامل 2. الحل: الخطوة 1: $\frac{1}{2}X(\omega/2)\Rightarrow x(2t)$ الطيف يتوسّع بمقدار 2 وينخفض. النتيجة: لا يمكن ضغط الزمن بلا توسيع التردّد. الربط بالذكاء الاصطناعي: تغييرُ معدّل العيّنات يغيّر عرض النطاق المطلوب.

مثال (51.2-10): طاقة الإشارة (بارسيفال المتّصل)

المعطيات: نريد $\int|x|^2dt$. الحل: الخطوة 1: $\int|x|^2dt=\frac{1}{2\pi}\int|X|^2d\omega$. النتيجة: الطاقة محفوظة في الصورة المتّصلة أيضاً. الربط بالذكاء الاصطناعي: تطبيعُ الطاقة في طبقات الشبكات يقرأ بالمعنى نفسه.

مثال (51.2-11): التحويل العكسي لإشارة مفلترة

المعطيات: $X(\omega)=\frac{1}{1+i\omega}$، والمطلوب: $x(t)$. الحل: الخطوة 1: من المثال (51.2-2): $x(t)=e^{-t}u(t)$. النتيجة: مطابقةٌ بالجدول لا بالتكامل المباشر. الربط بالذكاء الاصطناعي: الجداول الطيفية نظيرُ «pretrained priors» في النماذج.

مثال (51.2-12): التحويل لإشارة مركّبة (تحليلية)

المعطيات: إشارة تحليلية بطيفٍ للموجب فقط. الحل: الخطوة 1: $x_a = x + i\mathcal{H}\{x\}$ حيث $\mathcal{H}$ تحويل هيلبرت. الخطوة 2: مقدارُها مغلف الإشارة. النتيجة: استخراج المغلف والطور الآني. الربط بالذكاء الاصطناعي: تحليلُ الاهتزازات وتشخيص الأعطال.

مثال (51.2-13): التحويل في بعدين (صورة)

المعطيات: صورة $I(x,y)$، والمطلوب: طيفها. الحل: الخطوة 1: $I(u,v) = \iint I(x,y)e^{-2\pi i(ux+vy)}dxdy$ (تحويلٌ قابل للفصل). الخطوة 2: يُحسب بـFFT على الصفوف ثم الأعمدة. النتيجة: نفس النظرية في بُعدين. الربط بالذكاء الاصطناعي: الترشيح في مجال التردّد للصور وضغط JPEG.

مثال (51.2-14): التحويل وإزالة الضجيج

المعطيات: إشارة + ضجيج عالي التردّد. الحل: الخطوة 1: نقطع $|\omega| > \omega_c \Rightarrow$ يزول الضجيج ويبقى المحتوى. الخطوة 2: الثمن: فقدان التفاصيل الحادّة. النتيجة: ترشيحٌ بسيط بمبرهنة الالتفاف لاحقاً. الربط بالذكاء الاصطناعي: تنعيمُ التمثيلات في الشبكات يخفض الضجيج بالمنطق نفسه.

مثال (51.2-15): التحويل بوصفه تغيير قاعدة

المعطيات: قارن فوريه بـSVD. الحل: الخطوة 1: كلاهما إسقاط على قاعدة عمودية تحفظ الطاقة. الخطوة 2: فوريه قاعدةٌ ثابتة (عالمية)، وSVD قاعدةٌ متعلَّمة من البيانات. النتيجة: فوريه = استقراء قوي بلا تعلّم. الربط بالذكاء الاصطناعي: الأسس الطيفية بديلٌ عن الميزات المتعلَّمة حين تقلّ البيانات.

أخطاء شائعة

١. **الخلط بين f (هرتز) وω (راد/ثانية):** العامل 2π يتنقّل بين الصيغ.

٢. **نسيان $1/2\pi$ في التحويل العكسي:** أو توزيعها على الطرفين باصطلاح آخر.

٣. **تجاهل دالة ديراك للإشارات غير المتلاشية:** الطيف توزيع لا دالة.

٤. **الظنّ أن التفاضل آمن دائماً:** يضخّم التردّد العالي (والضجيج معه).

٥. **الخلط بين طيف القدرة وطيف المطال:** الأول $|X|^2$ والثاني $|X|$.

تمهيد قصصي

في الحاسوب لا يوجد «كلّ الزمن» ولا «كلّ التردّد»: يوجد N **رقم** فقط. فكيف نحسب الطيف؟ نُعيّن في الزمن (فتصير الإشارة متتالية $x[n]$) ونُعيّن في التردّد (فيصير الطيف متتالية $X[k]$). هكذا نحصل على **DFT**: تحويلٌ من N أرقام إلى N أرقام، لا أكثر ولا أقلّ.

ثم تأتي القفزة التي غيّرت القرن العشرين: حساب DFT المباشر يكلّف $O(N^2)$ عملية — أي نحو أربعة ملايين عملية لـ$N = 2048$. وخوارزمية **FFT** تحسبه بـ$O(N \log N)$ — نحو 23 ألفاً. **فرقٌ بمقدار مئتي ضعف، جعل معالجة** الإشارة الرقمية ممكنة في الزمن الحقيقي. وليس في ذلك سحر: FFT تلاحظ أنّ جذور الوحدة W_N^k فيها تناظرٌ دوري، فتقسّم المسألة إلى زوجيّ وفرديّ، وتعيد استخدام الحساب نفسه مرّتين.

صياغة رسمية

$$\text{DTFT:} X(e^{i\omega}) = \sum_{n=-\infty}^{\infty} x[n] e^{-i\omega n} \quad (\text{دوري بـ} 2\pi) \tag{1.3.51}$$

$$\text{DFT:} X[k] = \sum_{n=0}^{N-1} x[n]\, W_N^{kn}, \qquad W_N = e^{-2\pi i/N}, \qquad k = 0..N-1 \tag{2.3.51}$$

$$\text{IDFT:} x[n] = \frac{1}{N} \sum_{k=0}^{N-1} X[k]\, W_N^{-kn} \tag{3.3.51}$$

$$\text{(Cooley–Tukey): FFT} X[k] = E[k] + W_N^k O[k], \quad X[k+N/2] = E[k] - W_N^k O[k] \tag{4.3.51}$$

$$\text{التعقيد:} T(N) = 2T(N/2) + O(N) = O(N \log N), \qquad \text{ودقّة التردّد} \Delta f = \frac{f_s}{N} \tag{5.3.51}$$

جدول الرموز

الرمز	المعنى	ملاحظة
W_N	جذر الوحدة الأولي	$e^{-2\pi i/N}$
E, O	تحويلا الفهارس الزوجية والفردية	لبنة FFT
Δf	دقّة التردّد	تزيد بطول الإطار N
N	طول الإطار	يحدّد الدقّة والتكلفة
f_s	معدّل العيّنات	يحدّد أعلى تردّد $(f_s/2)$

برهان (مخطط)

١. **(2.3.51)** نعيّن الترددّات $\omega_k = 2\pi k/N$ في DTFT ونقتصر على N عيّنة $\Rightarrow$ الصيغة.

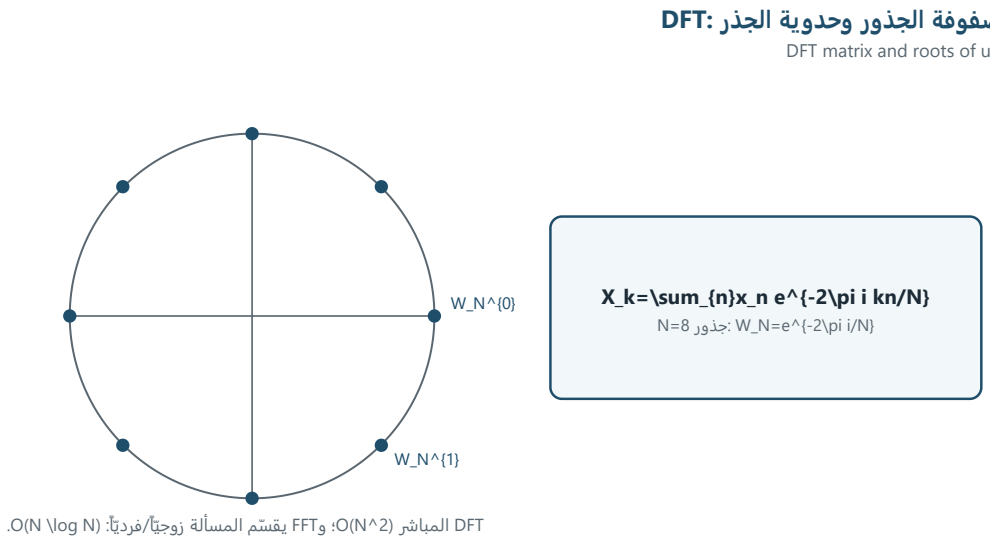
٢. **(4.3.51)** نقسّم المجموع إلى فهارس زوجية وفرادية: $X[k] = \sum x[2m] W_{N/2}^{km} + W_N^k \sum x[2m+1] W_{N/2}^{km}$؛ والحدّان هما DFT بطول $N/2$.

٣. **(5.3.51)** من علاقة التكرار: عمقٌ $\log_2 N$ وكلّ مستوى $O(N) \Rightarrow O(N \log N)$.

٤. **(العمليّة)** عدد العمليات: FFT $5N \log_2 N$ = مقابل DFT المباشر $4N^2$ = تقريباً. ■

شروط الصحّة: FFT الكلاسيكية تتطلّب N قوةَ اثنين (وإلا استخدم خوارزميات مختلطة الراديكس أو Bluestein). و DFT تفترض periode الإطار — ومنها يأتي التسرّب (6.51).

أمثلة محلولة (15)



شكل ٢.٥١: *
DFT ومصفوفة جذور الوحدة وخوارزمية FFT

مثال (1-3.51): DFT لإشارة ثابتة

المعطيات: $x[n] = 1$ للكلّ، $N = 8$. الحل: الخطوة 1: $X[0] = 8$ و$X[k] = 0$ للباقي (مجموع جذور الوحدة يصفّر). النتيجة: كلّ الطاقة عند التردّد الصفري (DC). الربط بالذكاء الاصطناعي: المكوّن المستمر؛ وفي الشبكات: الانحياز.

مثال (2-3.51): طيف نغمة مفردة

المعطيات: $x[n] = \cos(2\pi \cdot 2 \cdot n/8)$، $N = 8$. الحل: الخطوة 1: بالأويلر: نبضتان عند $k = 2$ و$k = 6$ بمقدار 4 لكلٍّ. النتيجة: تماثلٌ هيرميتي $X_{8-k} = \overline{X_k}$ ✓. الربط بالذكاء الاصطناعي: نصفُ الطيف يكفي (كما في 7.50).

مثال (3-3.51): تكلفة DFT مقابل FFT

المعطيات: $N = 1024$. الحل: الخطوة 1: مباشر $\approx 4 \times 10^6$ عملية؛ FFT $\approx 5 \times 10^4$ $\approx 5 \times 1024 \times 10$. النتيجة: تسريعٌ بنحو 80 ضعفاً. الربط بالذكاء الاصطناعي: مبرّرُ حساب الالتفاف الكبير في مجال التردّد.

مثال (4-3.51): دقة التردّد وطول الإطار

المعطيات: $f_s = 16$ kHz و$N = 256$. الحل: الخطوة 1: $\Delta f = 16000/256 = 62.5$ Hz. الخطوة 2: لدقّة 10 Hz نحتاج $N = 1600 \Rightarrow$ نختار 2048. النتيجة: الدقة تزيد خطّيّاً بطول الإطار. الربط بالذكاء الاصطناعي: مفاضلة الزمن (استجابة أسرع) مقابل التردّد (دقّة أعلى).

مثال (3.51-5): اختيار حجم FFT في الصوت

المعطيات: 16 kHz، ونريد إطاراً زمنيّاً 25 ms. الحل: الخطوة 1: $N = 0.025 \times 16000 = 400 \Rightarrow$ نختار 512 (قوة اثنين). الخطوة 2: $\Delta f = 31.25$ Hz ومدى التردّد 8 kHz في 256 خليّة موجبة. النتيجة: إعدادُ STFT القياسي لأنظمة الصوت. الربط بالذكاء الاصطناعي: أعداد log-mel الشائعة (40–80 مرشّحاً) مبنية على هذا.

مثال (3.51-6): حساب DFT باليد لـ $N = 4$

المعطيات: $x = [1, 2, 3, 4]$. الحل: الخطوة 1: $X[0] = 10$، $X[1] = 1 + 2(-i) + 3(-1) + 4(i) = -2 + 2i$. الخطوة 2: $X[2] = 1 - 2 + 3 - 4 = -2$، $X[3] = \overline{X[1]} = -2 - 2i$. النتيجة: طيفٌ متماثل هيرميتيّاً ✓. الربط بالذكاء الاصطناعي: تمرينٌ يؤسّس فهم المصفوفة قبل استخدام المكتبات.

مثال (3.51-7): FFT توفّر الوقت في الالتفاف

المعطيات: التفاف بطول إشارة 10^6 ونواة 10^3. الحل: الخطوة 1: مباشر $\approx 10^9$ عملية؛ FFT $\approx 5 \times 10^8$ $\Rightarrow 10^6 \log_2 10^6$ أسرع بـ10 أضعاف. النتيجة: FFT تتوفّق للنواة الطويلة فقط. الربط بالذكاء الاصطناعي: قاعدة عملية: النواة الصغيرة (3×3) مباشرة، الكبيرة عبر FFT.

مثال (3.51-8): طيّ الطيف (periodic spectrum)

المعطيات: طيف DFT عند $k > N/2$. الحل: الخطوة 1: $X[k]$ لـ $k > N/2$ يمثّل التردّد «السالب» $k - N$. الخطوة 2: إعادة الترتيب (fftshfit) تعرض الطيف من $-f_s/2$ إلى $f_s/2$. النتيجة: تمثيلٌ طبيعي للطيف. الربط بالذكاء الاصطناعي: خطأٌ شائع في رسم الأطياف وعرضها.

مثال (3.51-9): التهيئة الصفرية (zero padding)

المعطيات: نضيف أصفاراً لتصبح $N = 2048$ بدل 512. الحل: الخطوة 1: لا نضيف معلومات، لكن نستقرئ الطيف بين العيّنات $\Rightarrow$ طيفٌ أنعم بصريّاً. الخطوة 2: الدقة «الحقيقية» لم تتغيّر (محدودة بطول الإطار الأصلي). النتيجة: استقراءٌ لا تحسين. الربط بالذكاء الاصطناعي: تحذيرٌ من الخلط بين الاستقراء والدقة الفعلية.

مثال (3.51-10): تحويل حقيقي (rfft)

المعطيات: إشارة حقيقية بطول N. الحل: الخطوة 1: نخزّن $1 + N/2$ معاملاً فقط (تماثل هيرميتي). النتيجة: توفيرٌ بنسبة 50٪ في الحساب والذاكرة. الربط بالذكاء الاصطناعي: np.fft.rfft هو الخيار الافتراضي للمدخلات الحقيقية.

مثال (51.3-11): طيف صورة بـFFT ثنائي

المعطيات: صورة 512×512. الحل: الخطوة 1: FFT على الصفوف ثم الأعمدة: $\approx 9 \times 512 \times 512 \times 2$ 4.7×10^6 عملية. النتيجة: أسرع بأضعاف من الالتفاف المكاني بنواة كبيرة. الربط بالذكاء الاصطناعي: الترشيحُ الغاوسي الكبير يُحسب في مجال التردّد عادةً.

مثال (51.3-12): تحقّق من بارسيفال المنفصل

المعطيات: $x = [1, 2, 3, 4]$. الحل: الخطوة 1: $\sum |x_n|^2 = 30$، و$\frac{1}{N}\sum |X_k|^2 = \frac{1}{4}(100+8+4+8) = 30$ ✓. النتيجة: الطاقة محفوظة في الصورة المنفصلة. الربط بالذكاء الاصطناعي: اختبارٌ قياسي لأيّ تنفيذ FFT.

مثال (51.3-13): FFT في تدريب الشبكات

المعطيات: طبقة التفاف بنواة 64×64. الحل: الخطوة 1: التكلفة المباشرة $(64^2 \cdot O(N$ مقابل FFT $O(N \log N)$. النتيجة: FFT أرخص عند النوى الكبيرة جدّاً. الربط بالذكاء الاصطناعي: «FFT conv» في الشبكات الكبيرة والطبقات الطيفية.

مثال (51.3-14): حدود FFT في الأجهزة

المعطيات: حساب FFT على GPU بدفعات صغيرة. الحل: الخطوة 1: FFT حسّاسة للتوازي والنقل بين الذاكرة $\Rightarrow$ الدفعات الصغيرة لا تستفيد. النتيجة: المباشر قد يفوز عمليّاً رغم تعقيده الأسوأ. الربط بالذكاء الاصطناعي: التعقيد النظري $\neq$ الأداء على العتاد.

مثال (51.3-15): FFT والمويجات لاحقاً

المعطيات: إشارة متقطّعة تريد ضغطاً. الحل: الخطوة 1: FFT تعطي ذيلاً بطيئاً، وDWT تعقيدها $O(N)$ وتمثيلها أدنى (الفصل 52). النتيجة: لا أداة واحدة لكلّ المهام. الربط بالذكاء الاصطناعي: اختيارُ الأداة بحسب بنية الإشارة.

أخطاء شائعة

١. **الخلط بين DTFT (متّصل دوري) وDFT (منفصل):** الأول دالة، والثاني N رقم.

٢. **تجاهل تماثل الطيف للحقيقية:** هدرٌ بنسبة ٪50.

٣. **اعتبار zero-padding يزيد الدقة:** يزيد استقراء العرض فقط.

٤. **استخدام FFT للنواة الصغيرة ظنّاً أنها أسرع:** المباشر أسرع تحت عتبة معيّنة.

٥. **نسيان أن DFT يفترض دورية الإطار:** مصدرُ التسرّب الطيفي.

تمهيد استفهامي

صورةٌ لعجلة سيارة في فيديو تبدو كأنّها تدور **بالعكس.** هل رأيت ذلك؟ هذا ليس خللاً في الكاميرا بل في **معدّل العيّنات**: العجلة تدور أسرع مما تستطيع الكاميرا أن تميّز، فتُقرأ الحركةُ السريعة حركةً بطيئة معكوسة. هذه هي الظاهرة التي تسمّى aliasing في أبسط صورها، ونظرية نيكويست–شانون هي التي تحدّد متى تسلم منها.

والقاعدة الذهبية: إن كان أعلى تردّد في إشاراتك B هرتز، فعيِّنْ بأكثر من $2B$ هرتز. لا «حوالي» ولا «تقريباً»: **أكثر** — فالمساواة بالضبط حالةٌ حرجة تفشل عملياً. وهذا هو سبب اختيار 1.44 kHz للقرص المضغوط: لأنّ أذن الإنسان تسمع حتى 20 kHz، فاحتاجوا هامشاً فوق 40 kHz.

صياغة رسمية

ليكن $x(t)$ محدود النطاق: $X(\omega)=0$ لكلّ $|\omega|>\omega_B=2\pi B$. فإنّ:

$$x(t)=\sum_{n=-\infty}^{\infty} x(nT_s)\,\mathrm{sinc}\!\left(\frac{t}{T_s}-n\right), \qquad \mathrm{sinc}(u)=\frac{\sin(\pi u)}{\pi u} \tag{1.4.51}$$

شرط نيكويست: $f_s=\dfrac{1}{T_s} \;>\; 2B$ (2.4.51)

في مجال التردّد: $X_s(\omega)=\dfrac{1}{T_s}\sum_{k=-\infty}^{\infty} X(\omega-k\omega_s), \qquad \omega_s=\dfrac{2\pi}{T_s}$ (3.4.51)

التداخل ممنوع: $\omega_s-\omega_B>\omega_B \iff \omega_s>2\omega_B$ (4.4.51)

جدول الرموز

الرمز	المعنى	ملاحظة
T_s	زمن العيّنة	و$f_s=1/T_s$
B	عرض النطاق	أعلى تردّد موجود
ω_s	تردّد العيّنة الزاوي	$=2\pi/T_s$
sinc	نواة إعادة البناء	$\sin(\pi u)/(\pi u)$
X_s	طيف الإشارة المعيّنة	نسخٌ متكرّرة من الطيف

برهان (مخطط)

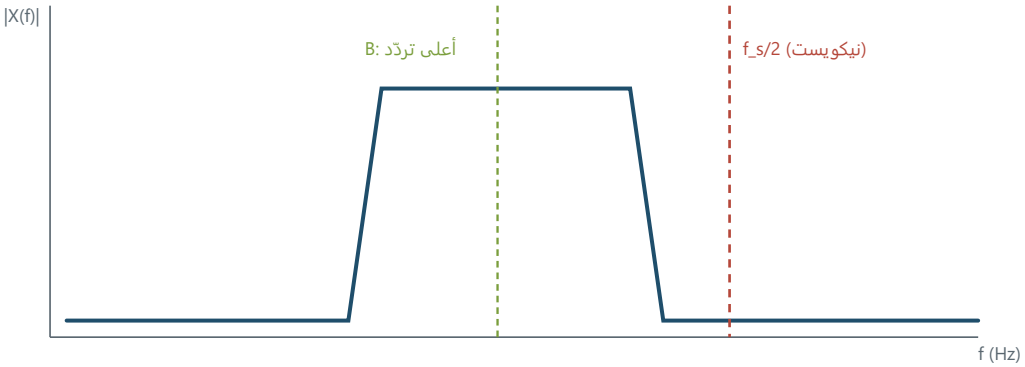
١. **(3.4.51)** العيّنة = ضربُ الإشارة بمشط ديراك بخطوة T_s؛ والضرب في الزمن = الالتفاف في التردّد (بمقياس) ⇒ نسخٌ من الطيف متباعدة بـω_s.

٢. **(4.4.51)** النسخ لا تتداخل iff التباعد أكبر من عرض النطاق مضاعفاً ⇒ $\omega_s>2\omega_B$.

٣. **(1.4.51)** نضرب طيف النسخ بمرشّح تمرير منخفض مثالي (مستطيل على $|\omega|<\omega_s/2$)؛ وعكسُه في الزمن هو الالتفاف بمشط العيّنات مضروباً بـsinc ⇒ صيغة إعادة البناء. ■

شروط الصحّة: الإشارة يجب أن تكون **محدودة النطاق تماماً** (وهو مثالي؛ في الواقع نرشّح قبل العيّنة). ومرشّح إعادة البناء المثالي غير سببي وغير قابل للتحقيق تماماً — نكتفي بتقريبات (الاحتفاظ بالعيّنات zero-order hold، أو الاستقراء الخطّي، أو مرشّح تناظري).

نيكويست–شانون: شرط معدّل العيّنات
Nyquist–Shannon sampling theorem



الشرط: $f_s > 2B$. وإلا تداخل الطيف (aliasing) ولا يمكن إعادة البناء.

إعادة البناء: $x(t)=\sum_n x[n]\,\mathrm{sinc}\!\left(t/T-n\right)$.

شكل ٥١.٣: *
نظرية نيكويست-شانون: شرط معدل العينات وإعادة البناء بنواة sinc

أمثلة محلولة (15)

مثال (51.4-1): اختيار معدّل عيّنات للصوت

المعطيات: أعلى تردّد مطلوب 20 kHz. الحل: الخطوة 1: نيكويست يقتضي $f_s > 40$ kHz. الخطوة 2: القرص المضغوط يختار 44.1 kHz (هامش 2 kHz للمرشّح التناظري). النتيجة: الهامش ضرورةٌ هندسية لا ترف. الربط بالذكاء الاصطناعي: الهوامش في التصميم نظيرُ التنظيم في التعلّم.

مثال (51.4-2): إعادة بناء بـsinc

المعطيات: عيّنات عند $t = 0, 1, 2$ بقيم $1, 0, -1$. الحل: الخطوة 1: $x(t) = 1\cdot\mathrm{sinc}(t) + 0 - 1\cdot\mathrm{sinc}(t-2)$. الخطوة 2: عند $t = 1$: $\mathrm{sinc}(1) - \mathrm{sinc}(-1) = 0 - 0 = 0$ ✓ (الاستقراء يعيد العيّنات). النتيجة: إعادة البناء تحترم العيّنات نفسها بالضرورة. الربط بالذكاء الاصطناعي: الاستقراء (interpolation) في الشبكات يخضع للقيود نفسها.

مثال (51.4-3): كم عيّنة تكفي لنغمة 1 kHz؟

المعطيات: نغمة نقيّة 1 kHz. الحل: الخطوة 1: $B = 1$ kHz $\Rightarrow f_s > 2$ kHz: نختار 8 kHz عمليّاً. النتيجة: عيّنتان لكلّ دورة حدٌّ نظري أدنى. الربط بالذكاء الاصطناعي: القليل جدّاً من العيّنات يعطي نموذجاً واثقاً من وهم.

مثال (4-4.51): ماذا لو ساوى $f_s = 2B$ تماماً؟

المعطيات: نغمة عند B تماماً بـ$f_s = 2B$. الحل: الخطوة 1: قد تُعيَّن النغمة كلّها عند الأصفار $\Rightarrow$ نحصل صفراً. النتيجة: الحدّ الحرج يفشل — الشرط صارم $<$. الربط بالذكاء الاصطناعي: الحدود الحرجة في الرياضيات نادراً ما تعمل هندسيّاً.

مثال (5-4.51): مرشّح مضاد للتشويه

المعطيات: إشارة حتى 30 kHz ونريد العيّنة عند 44.1 kHz. الحل: الخطوة 1: نيكويست = 60 kHz $\Rightarrow$ يجب قطع ما فوقها قبل العيّنة. الخطوة 2: مرشّح تناظري منخفض التمرير بانتقال 20→22 kHz. النتيجة: المرشّح المضادّ شرطٌ لا كمال. الربط بالذكاء الاصطناعي: preprocessing قبل التعلّم نظيرُه تماماً.

مثال (6-4.51): العيّنة الفوقية (oversampling)

المعطيات: نعيّن بـ4 أضعاف نيكويست. الحل: الخطوة 1: النسخ الطيفية متباعدة $\Rightarrow$ مرشّح إعادة بناء أبسط وأرخص. الخطوة 2: الثمن: بيانات أكثر. النتيجة: مقايضةٌ كلاسيكية. الربط بالذكاء الاصطناعي: البيانات الأكثر مقابل نموذج أبسط — مفاضلة معروفة.

مثال (7-4.51): تقليل العيّنات (decimation)

المعطيات: إشارة 48 kHz نريد تحويلها إلى 16 kHz. الحل: الخطوة 1: نرشّح أولاً بقطع عند 8 kHz، ثم نأخذ عيّنة من كلّ ثلاث. الخطوة 2: بلا المرشّح: تشويهٌ طيفي لا رجعة فيه. النتيجة: الترشيح قبل التقليل إلزامي. الربط بالذكاء الاصطناعي: اختزالُ الأبعاد بلا تصفية يفقد معلومات ثمينة.

مثال (8-4.51): رفع العيّنات (interpolation)

المعطيات: نضاعف معدّل العيّنات. الحل: الخطوة 1: نُدخل أصفاراً بين العيّنات $\Rightarrow$ تظهر نسخٌ طيفية «مرايا». الخطوة 2: نرشّح بتمرير منخفض لإزالة المرايا. النتيجة: استقراءٌ نظيف. الربط بالذكاء الاصطناعي: رفعُ الدقة في الصور (upsampling) بالمنطق نفسه.

مثال (9-4.51): تشويه بصري (عجلة السيارة)

المعطيات: كاميرا 24 إطاراً/ث، عجلة تدور 25 دورة/ث. الحل: الخطوة 1: التردّد الفعلي 25 أعلى من نيكويست 12 $\Rightarrow$ يُقرأ كـ$25 - 24 = 1$ دورة/ث بالاتجاه نفسه تقريباً. النتيجة: وهمٌ بصري كامل. الربط بالذكاء الاصطناعي: العيّنات النادرة تخلق أنماطاً وهمية يتعلّمها النموذج بثقة.

مثال (51.4-10): تشويه في الصور (moiré)

المعطيات: قماشٌ دقيق يُصوَّر بمستشعر بدقة مشابهة. الحل: الخطوة 1: التردّد المكاني العالي يُقرأ منخفضاً ⇒ أنماط moiré. الخطوة 2: العلاج: مرشّح تمرير منخفض بصري (anti-alias في المستشعر). النتيجة: نفس الظاهرة في بُعدين. الربط بالذكاء الاصطناعي: CNNs أيضاً تعاني من تشويه الاختزال (aliased pooling).

مثال (51.4-11): تعلّمٌ بعيّنات نادرة

المعطيات: ظاهرة دورية نختبرها بمعدّل أقل من نيكويست. الحل: الخطوة 1: النموذج «يرى» دورةً أطول غير موجودة. الخطوة 2: تعميمه سيكون خاطئاً بثقة عالية. النتيجة: تحذيرٌ منهجي من تكرار التجارب النادر. الربط بالذكاء الاصطناعي: تصميمُ التجارب = تصميمُ معدّل العيّنات.

مثال (51.4-12): قياس عرض النطاق عملياً

المعطيات: إشارة مجهولة، والمطلوب: تحديد B قبل العيّنة. الحل: الخطوة 1: نحلّل طيفها بعيّنة عالية مؤقّتاً، ونجد التردّد الذي يتلاشى بعده الطيف. الخطوة 2: نضيف هامشاً 10–20٪. النتيجة: قرارُ العيّنة مدعومٌ بقياس لا حدس. الربط بالذكاء الاصطناعي: تحليلُ البيانات قبل اختيار معدّل أخذ العيّنات.

مثال (51.4-13): نيكويست في الفيديو

المعطيات: حركةٌ سريعة بـ30 إطاراً/ث. الحل: الخطوة 1: التردّد المكاني-الزمني يحدد الحدّ، وتقنيات التمويه (motion blur) تعمل مرشّحاً مضادّاً طبيعيّاً. النتيجة: التمويه ليس عيباً بل مرشّح. الربط بالذكاء الاصطناعي: التنعيم المتعمّد في البيانات وسيلةُ منع التشويه.

مثال (51.4-14): النسخ الطيفية في DFT

المعطيات: لماذا يظهر الطيف مكرّراً في DFT؟ الحل: الخطوة 1: لأن العيّنة في الزمن تجعل الطيف دوريّاً بـf_s (51.4.3). النتيجة: التكرار بنيوي لا عَرَضي. الربط بالذكاء الاصطناعي: فهمُ البنية يمنع تفسير التكرار خطأً.

مثال (51.4-15): إعادة البناء العمليّة

المعطيات: مكتبة صوت تعيد بناء الموجة من العيّنات. الحل: الخطوة 1: الاستقراء الخطّي/الsinc المقطوع عملياً أرخص من sinc اللامتناهي. الخطوة 2: الخطأ يُقاس بالطاقة خارج النطاق. النتيجة: تقريبٌ محسوب لا مثاليّ. الربط بالذكاء الاصطناعي: المُرمِّزات العصبية تتعلّم هذا الاستقراء بدل وصفه (الفصل 53).

أخطاء شائعة

١. **الاكتفاء بـ** $f_s = 2B$: الشرط صارم $<$.

٢. **تقليل العيّنات بلا ترشيح مسبق:** تشويهٌ لا رجعة فيه.

٣. **نسيان المرشّح المضادّ قبل العيّنة:** النظرية تفترض محدود النطاق.

٤. **الظنّ أن العيّنة «فقدان» فقط:** هي طيٌّ للطيف يختلط بالباقي.

٥. **تجاهل الهامش العملي للمرشّحات التناظرية:** الانتقال ليس حادّاً.

تمهيد قصصي

عدّادُ سيّارةٍ رقمي، وكاميرا مراقبة، ومستشعرُ اهتزاز في مصنع: كلّها «ترى» ما ليس موجوداً حين تخالف نيكويست. الأسوأ أنّ الخطأ **لا يبدو خطأً**: الإشارة الناتجة ناعمة، مقنعة، ومعقولة تماماً — لكنّها كذبة متقنة. لا علامة حمراء، ولا «خطأ في القياس»؛ مجرّد رقمٍ معقول عن ظاهرةٍ مختلفة.

في التعلّم العميق هذه أخطرُ أنواع الفشل: نموذجٌ يتعلّم نمطاً **موجوداً في العيّنات فقط** (artfiact) ويُعمّمه بثقة. لذا فإنّ مكافحة التشويه ليست تفصيلاً هندسيّاً، بل عقيدة: **رشّح قبل أن تختزل** — سواء كانت البيانات صوتاً أم صوراً أم مجموعة تدريب.

صياغة رسمية

العيّنة تحت نيكويست: $f_{\text{مرئي}} = |f_{\text{أصلي}} - k f_s| \quad k \in \mathbb{Z}$ الأقرب (1.5.51)

طيّ الطيف: $X_s(\omega) = \frac{1}{T_s} \sum_k X(\omega - k\omega_s)$ ⇐ التداخل يجمع الطاقات (2.5.51)

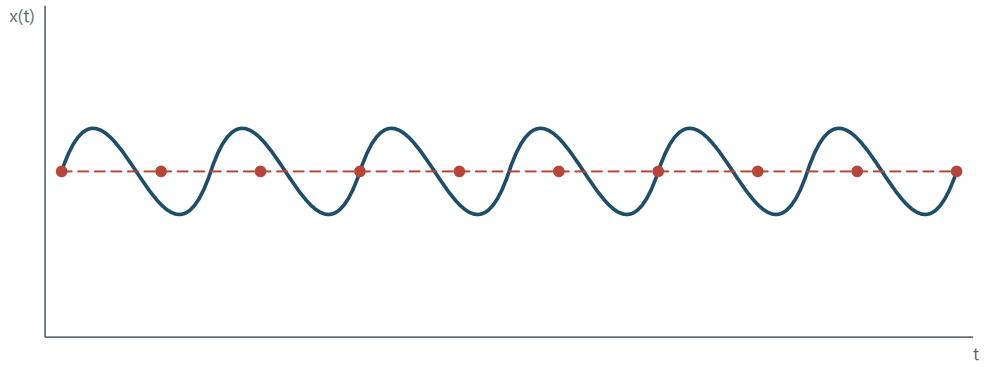
المكافحة: $\tilde{x} = (h_{\text{LP}} * x)$ ثم العيّنة بـ $f_s, \qquad H_{\text{LP}}(\omega) = 0$ لـ $|\omega| > \omega_s/2$ (3.5.51)

الطاقة المشوّهة: $E_{\text{alias}} = \int_{|\omega| > \omega_s/2} |X(\omega)|^2 d\omega$ (4.5.51)

جدول الرموز

الرمز	المعنى	ملاحظة
$f_{\text{مرئي}}$	التردّد الذي سنراه	نتيجة الطيّ
k	عدد الانزياحات الطيفية	يُقرّب التردّد إلى النطاق
h_{LP}	مرشّح تمرير منخفض	مانع التشويه
E_{alias}	طاقة ما سيُشوَّه	تُقاس قبل العيّنة
$\omega_s/2$	تردّد نيكويست	حدّ الأمان

التردّد العالي يتنكّر (Aliasing): التشويه الطيفي
Aliasing: high frequency masquerades as low



العيّنات (النقاط الحمراء) توافق إشارةً منخفضة التردّد تماماً ⇒ لا تمييز بعد العيّنة.

العلاج: مرشّح تمرير منخفض قبل العيّنة (anti-alias)، أو رفع f_s.

شكل ٥١.٤: *
التشويه الطيفي: عينات إشارة عالية التردد توافق إشارة منخفضة التردد

برهان (مخطط)

١. **(1.5.51)** من دورية الطيف (3.4.51): التردّد f و$f - f_s$ و$f + f_s$ يعطون العيّنات نفسها ⇒ لا تمييز.

٢. **(2.5.51)** عند التداخل تجمعُ النسخ قيماً فوق بعضها ⇒ لا يمكن فصلها بأيّ مرشّح لاحق.

٣. **(3.5.51)** قطعُ المحتوى فوق $\omega_s/2$ **قبل** العيّنة يمنع التداخل ⇒ الاستعادة ممكنة.

٤. **(4.5.51)** ببارسيفال: الطاقة الخارجية هي ما سيُطوى. ■

شروط الصحّة: التشويه **لا رجعة فيه** بعد العيّنة — Prevention لا cure. والمرشّح المثالي غير قابل للتحقيق؛ العملي يترك هامش انتقال (guard band).

أمثلة محلولة (15)

مثال (1-5.51): حساب التردّد المرئي

المعطيات: $f_s = 1000$ Hz وإشارة $f = 1200$ Hz. الحل: الخطوة 1: $f_{\text{مرئي}} = |1200 - 1000| = 200$ Hz. النتيجة: نرى 200 Hz بدل 1200. الربط بالذكاء الاصطناعي: النموذج يتعلّم تردّداً ليس موجوداً.

مثال (2-5.51): تردّد فوق نيكويست مباشرة

المعطيات: $f_s = 800$ Hz و$f = 700$ Hz (نيكويست 400). الحل: الخطوة 1: $|700 - 800| = 100$ Hz مرئي. النتيجة: 100 Hz. الربط بالذكاء الاصطناعي: عيّناتٌ متقاربة زمنيّاً تخفي ظواهر سريعة.

مثال (51.5-3): تشويه في رسم الإشارة

المعطيات: نغمة 9 Hz بعيّنة 10 Hz. الحل: الخطوة 1: $|9 - 10| = 1$ Hz $\Rightarrow$ نرى موجة بطيئة جدّاً. النتيجة: وهمٌ كامل. الربط بالذكاء الاصطناعي: الرسم البياني الخاطئ أخطر من غيابه.

مثال (51.5-4): قياس الطاقة المشوّهة

المعطيات: إشارة طاقتها 90٪ تحت 4 kHz و10٪ فوقها، و$f_s = 8$ kHz. الحل: الخطوة 1: نيكويست 4 kHz $\Rightarrow$ الـ10٪ ستُشوَّه وتُضاف للتردّدات المنخفضة. النتيجة: تشويهٌ بنسبة 10٪ من الطاقة. الربط بالذكاء الاصطناعي: تقديرُ الضرر قبل اتّخاذ القرار.

مثال (51.5-5): مرشّح مضادّ قبل العيّنة

المعطيات: إشارة حتى 6 kHz، نريد $f_s = 8$ kHz. الحل: الخطوة 1: نرشّح بقطع عند 5.3 kHz (هامش تحت 4). الخطوة 2: نفقد المحتوى 5.3–6 kHz عمداً — لكن بلا تشويه. النتيجة: فقدانٌ نظيف خيرٌ من تشويه خفيّ. الربط بالذكاء الاصطناعي: حذفُ ميزات مشكوك فيها أفضل من تعلّم أنماط وهمية.

مثال (51.5-6): التشويه في الاختزال (pooling)

المعطيات: شبكة CNN تختزل بـmax-pool بلا Blur. الحل: الخطوة 1: الاختزال عيّنة $\Rightarrow$ تشويه مكاني $\Rightarrow$ المميّزات حسّاسة للإزاحة بكسل واحد. الخطوة 2: إضافة مرشّح (BlurPool) تحسّن الثبات. النتيجة: CNNs «anti-aliased» تحسّن التعميم فعليّاً. الربط بالذكاء الاصطناعي: مثالٌ حديث على نظرية قديمة تحلّ مشكلة معاصرة.

مثال (51.5-7): التشويه في augmentation

المعطيات: تدوير صورة باستقراء رخيص. الحل: الخطوة 1: الاستقراء دون ترشيح يُدخل تردّدات عالية وهمية. الخطوة 2: النموذج قد يتعلّمها كـartifact. النتيجة: مكافحة التشويه في خطوات preprocessing كلّها. الربط بالذكاء الاصطناعي: جودةُ التكبير تؤثّر في جودة التعلّم.

مثال (51.5-8): النطاق الحارس (guard band)

المعطيات: مرشّح عملي بانتقال من 18 إلى 22 kHz عند $f_s = 48$ kHz. الحل: الخطوة 1: نيكويست 24 kHz $\Rightarrow$ الهامش 2 kHz كافٍ لانتقال المرشّح. النتيجة: تصميمٌ واقعي. الربط بالذكاء الاصطناعي: الهوامش في كلّ تصميم هندسي محسوبة لا عشوائية.

مثال (51.5-9): تشويه في القياسات العلمية

المعطيات: مستشعر حرارة يُقرأ كلّ ساعة وظاهرة دورية كلّ 40 دقيقة. الحل: الخطوة 1: نيكويست يقتضي قراءة كلّ أقلّ من 20 دقيقة ⇒ التشويه واقع. النتيجة: قياسٌ ينتج علماً زائفاً. الربط بالذكاء الاصطناعي: تصميمُ وتيرة جمع البيانات مسألةُ صحّة استنتاج.

مثال (51.5-10): كشف التشويه من الطيف

المعطيات: طيفٌ فيه قمم «غريبة» بترددات منخفضة غير متوقّعة. الحل: الخطوة 1: نتحقّق: هل هي $|f - kf_s|$ لترددات عالية معروفة؟ النتيجة: تشخيصٌ رياضي بدل إعادة القياس. الربط بالذكاء الاصطناعي: فحصُ artfiacts قبل إلقاء اللوم على النموذج.

مثال (51.5-11): العيّنة الفوقية كعلاج

المعطيات: مستشعر رخيص بعيّنة منخفضة. الحل: الخطوة 1: نعيّن فوقيّاً في العتاد ثم نرشّح رقميّاً ثم نقلّل ⇒ نطاقٌ ديناميّ أفضل. النتيجة: تقنيةُ sigma-delta. الربط بالذكاء الاصطناعي: المعالجةُ الرقمية تعوّض محدودية العتاد.

مثال (51.5-12): التشويه الزمني في الفيديو

المعطيات: وميض LED بتردّد 100 Hz يُصوَّر بـ30 إطاراً. الحل: الخطوة 1: يُقرأ نمطاً أبطأ متغيّراً ⇒ وميض وهميّ. النتيجة: خطأٌ بصري منهجي. الربط بالذكاء الاصطناعي: أنظمة الرؤية الصناعية تحتاج نيكويست زمنيّاً أيضاً.

مثال (51.5-13): لا يمكن التراجع

المعطيات: عيّنّا بلا مرشّح، هل يمكن الإصلاح رقميّاً؟ الحل: الخطوة 1: لا — الطيّ جمع الطاقات في الخلايا نفسها بلا تمييز. النتيجة: الوقاية وحدها. الربط بالذكاء الاصطناعي: بعض أخطاء خطوط البيانات لا تُصلح لاحقاً.

مثال (51.5-14): تشويه في الصوت الرقمي

المعطيات: أخذ عيّنة نغمة 22 kHz بـ$f_s = 40$ kHz. الحل: الخطوة 1: $|22 - 40| = 18$ kHz ⇒ نغمة وهمية مسموعة 18 kHz. النتيجة: أثرٌ سمعي مزعج. الربط بالذكاء الاصطناعي: جودةُ التوليد الصوتي مرتبطةٌ بهذه الحدود.

مثال (51.5-15): تصميمُ تجربة تعلّم بلا تشويه

المعطيات: ظاهرة دورية بفترة مجهولة، ونخطّط لأخذ عيّنات. الحل: الخطوة 1: نعيّن أولاً بكثافة عالية لتقدير أعلى تردّد، ثم نحدّد الوتيرة الدنيا. النتيجة: منهجيةٌ سليمة لجمع البيانات. الربط بالذكاء الاصطناعي: «تصميم التجارب»

فرعٌ من نظرية العيّنات.

أخطاء شائعة

١. **محاولة إصلاح التشويه بعد العيّنة:** مستحيل رياضيّاً.

٢. **الاكتفاء بمرشّح رقمي بعد العيّنة:** الضرر وقع.

٣. **نسيان أن التشويه يظهر بمظهر معقول:** لا علامة تحذير.

٤. **تجاهل النطاق الحارس للمرشّح العملي:** التشويه يتسلّل من الانتقال.

٥. **الظنّ أن التشويه يخصّ الصوت فقط:** هو في الصور والزمن والرسوم.

تمهيد استفهامي

الترشيح — أهمّ عملية في معالجة الإشارة — هو التفافٌ في الزمن: $y[n] = \sum h_k x[n-k]$، بتكلفة $O(N \cdot L)$. لكنّ مبرهنة الالتفاف تقول: **في مجال التردّد هو مجرّد ضرب.** فننتقل بـFFT $(O(N \log N))$، ونضرب، ونعود بـFFT عكسي — فنوفر أضعافاً.

لكنّ «الانتقال» ليس مجّانيّاً: فنحن نحلل **إطاراً محدوداً** من إشارةٍ لانهائية، وهذا القطع نفسه «نافذة» تُضرب بها الإشارة، وضربٌ في الزمن = التفافٌ في التردّد ⇒ **تسرّب طيفي**: طاقة التردّد النقيّ تفيض على جيرانه. فلا مفرّ من مفاضلة: نافذة ضيّقة في التردّد (فصّ رئيسي دقيق) = ذيل طويل (تسرّب كثير)، والعكس. إنها مبدأ الريبة مرّة أخرى (الفصل 52).

صياغة رسمية

$$\mathcal{F}\{h * x\} = H(\omega)\,X(\omega), \qquad \mathcal{F}\{h \cdot x\} = \frac{1}{2\pi}(H * X)(\omega) \tag{1.6.51}$$

منفصلاً: $$(h * x)[n] = \sum_k h_k x_{n-k} \;\rightleftharpoons\; \mathrm{DFT}\{\mathrm{zeropad}(h)\}\,X[k] \tag{2.6.51}$$

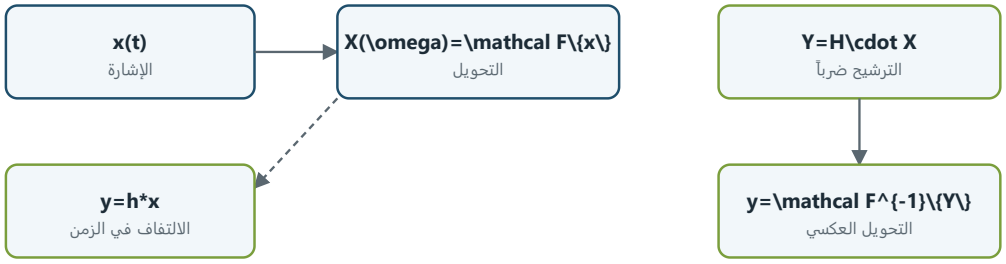
النافذة: $$x_w[n] = x[n]w[n] \;\Rightarrow\; X_w(\omega) = \frac{1}{2\pi}(X * W)(\omega) \tag{3.6.51}$$

مفاضلة النافذة: $\Delta\omega_{\text{فصّ}} \cdot$ مستوى الفصوص $\approx$ ثابت للنافذة (4.6.51)

جدول الرموز

الرمز	المعنى	ملاحظة
$h * x$	الالتفاف في الزمن	الترشيح
$H \cdot X$	الضرب في التردّد	الترشيح السريع
$w[n]$	النافذة (Hann/Hamming/Blackman)	تحدّد شكل الطيف
الفصّ الرئيسي	عرض قمّة النافذة الطيفية	دقّة التردّد
الفصوص الجانبية	ذيل النافذة	مقدار التسرّب

مبرهنة الالتفاف: الترشيح ضربٌ في مجال التردّد
Convolution theorem: filtering = multiplication



تكلفة الالتفاف المباشر $O(N\cdot L)$ مقابل $O(N\log N)$ عبر FFT.

شكل ٥٠٥١: *
مبرهنة الالتفاف: الترشيح ضرب في مجال التردد

برهان (مخطط)

١. **(1.6.51)** نكتب $\mathcal{F}\{h*x\}=\iint h(\tau)x(t-\tau)e^{-i\omega t}d\tau dt$؛ بالتعويض $u=t-\tau$ ينفصل التكاملان $\Rightarrow H(\omega)X(\omega)$.

٢. **(3.6.51)** الضرب في الزمن يقابل الالتفاف في التردّد بالعكس (تناظر الصيغتين).

٣. **(4.6.51)** من مبدأ الريبة: نافذة أطول ⇒ فصّ أضيق؛ ونافذة أنعم (Hann) ⇒ فصوص أخفض وفصّ أعرض. ■

شروط الصحّة: الالتفاف بالـDFT دوري (circular) — وللحصول على الالتفاف الخطّي يجب التهيئة الصفرية بطول $N\geq N_x+N_h-1$. والتسرّب لا يُلغى بل يُدار بالمفاضلة.

أمثلة محلولة (15)

مثال (1-6.51): ترشيح بسيط في مجال التردّد

المعطيات: إشارة بنغمتين، ونريد إزالة العالية. الحل: الخطوة 1: نحسب الطيف، نضرب بمرشّح يصفّر $|\omega|>\omega_c$، ثم نعكس. النتيجة: إزالةٌ نظيفة. الربط بالذكاء الاصطناعي: كلّ ترشيحٍ رقمي يبدأ من هذه المبرهنة.

مثال (2-6.51): الالتفاف الدوري مقابل الخطّي

المعطيات: إشارة طولها 4 ونواة طولها 3، بـDFT بطول 4. الحل: الخطوة 1: النتيجة التفافٌ دوري (يتداخل الذيل مع البداية) ×. الخطوة 2: نُهيّئ بصفر إلى 6 على الأقل ⇒ التفافٌ خطّي صحيح. النتيجة: شرطُ الطول

$N_x + N_h - 1$. الربط بالذكاء الاصطناعي: أخطاءُ «wrap-around» تظهر في كلّ حساب التفاف سريع.

مثال (51.6-3): تكلفة الالتفاف

المعطيات: $N = 10^6$ ونواة $L = 1000$. الحل: الخطوة 1: مباشر $\approx 10^9$؛ FFT $\approx 1.5 \times 10^8$ $\Rightarrow$ أسرع بنحو 7 أضعاف. النتيجة: FFT تتوفّق عند النوى الطويلة. الربط بالذكاء الاصطناعي: قاعدة: $L > 32$ تقريباً نقطة التحول.

مثال (51.6-4): تسرّب نافذة مستطيلة

المعطيات: نغمة نقيّة وn لا يطابق خليّة DFT تماماً. الحل: الخطوة 1: تنتشر الطاقة على كلّ الخلايا (ذيل sinc). النتيجة: تسرّبٌ واضح. الربط بالذكاء الاصطناعي: الطيف «الوسخ» سببُه النافذة لا الإشارة.

مثال (51.6-5): نافذة Hann

المعطيات: $w[n] = 0.5 - 0.5\cos(2\pi n/N)$. الحل: الخطوة 1: الفصوص الجانبية أخفض بـ31 dB $\Rightarrow$ تسرّب أقلّ. الخطوة 2: الثمن: الفصّ الرئيسي أعرض بمرّتين $\Rightarrow$ دقّة تردّد أقلّ. النتيجة: مفاضلة واضحة. الربط بالذكاء الاصطناعي: التنعيم مقابل الدقة (التحيز–التباين مرّة أخرى).

مثال (51.6-6): اختيار النافذة للمهام

المعطيات: نريد فصل نغمتين متقاربتين جدّاً. الحل: الخطوة 1: نحتاج فصّاً ضيّقاً $\Rightarrow$ نافذة مستطيلة (أو طويلة). الخطوة 2: وإن أردنا كشف نغمة ضعيفة قرب قوية $\Rightarrow$ نافذة Hann. النتيجة: النافذة بحسب المهمة. الربط بالذكاء الاصطناعي: النافذة = استقراء (inductive bias).

مثال (51.6-7): تسرّب في تحليل الصوت

المعطيات: إطار 25 ms بـHann. الحل: الخطوة 1: الفصّ $2 \times 40 = 80$ Hz $\Rightarrow$ نغمتان بفاصل أقلّ من ذلك تندمجان. النتيجة: حدودُ دقة التحليل. الربط بالذكاء الاصطناعي: عدد مرشّحات mel يحدّده هذا العرض.

مثال (51.6-8): الترشيح في الصور

المعطيات: صورة + مرشّح غاوسي كبير. الحل: الخطوة 1: FFT للصورة والنواة، ضرب، عكس $\Rightarrow$ أسرع بأضعاف من الالتفاف المكاني. النتيجة: تقنيةٌ قياسية في معالجة الصور. الربط بالذكاء الاصطناعي: طبقاتُ «conv» في الشبكات الكبيرة.

مثال (51.6-9): التهيئة الصفرية لا تضيف معلومات

المعطيات: نزيد الطول لتحسين عرض الطيف. الحل: الخطوة 1: الاستقراء بين النقاط الطيفية؛ الدقة الحقيقية ثابتة. النتيجة: لا تخلط بين الاستقراء والدقة. الربط بالذكاء الاصطناعي: تحسينُ العرض $\neq$ تحسين المعرفة.

مثال (51.6-10): التداخل بين الإطارات (overlap)

المعطيات: STFT بإطار 512 وقفزة 128 (75٪ تداخل). الحل: الخطوة 1: التداخل يعوّض توهين النافذة عند الأطراف $\Rightarrow$ إعادة بناء أفضل (OLA). النتيجة: تحليلٌ أكثر سلاسة. الربط بالذكاء الاصطناعي: التداخل نظيرُ الالتفاف بخطوة 1 في الشبكات.

مثال (51.6-11): حساب طاقة عبر الضرب

المعطيات: نريد طاقة الخرج بعد الترشيح. الحل: الخطوة 1: ببارسيفال: $E_y = \frac{1}{2\pi}\int |H|^2 |X|^2 d\omega$ — بلا حساب y. النتيجة: حسابٌ في مجال التردّد فقط. الربط بالذكاء الاصطناعي: تقييمُ أثر المرشّح قبل تنفيذه.

مثال (51.6-12): مرشّح مثالي غير قابل للتحقيق

المعطيات: قطعٌ حادّ في التردّد. الحل: الخطوة 1: استجابته النبضية sinc لا متناهية وغير سببية $\Rightarrow$ نقطعها ونواجه «رنين» (غيبس!). النتيجة: علاجٌ بمرشّح ذي انتقال ناعم. الربط بالذكاء الاصطناعي: النعومة في التصميم تحمي من الآثار الاصطناعية (4.50).

مثال (51.6-13): التفاف في الشبكات = ترشيح متعلَّم

المعطيات: طبقة التفاف بنواة 3×3. الحل: الخطوة 1: النواة مرشّح FIR قصير؛ وتعلّمها = تصميم مرشّح بالبيانات. النتيجة: CNN = بنك مرشّحات متعلَّم. الربط بالذكاء الاصطناعي: هذا هو أعمق ربط بين الفصل والشبكات الالتفافية (الفصل 37).

مثال (51.6-14): المويجات أفضل عند الحاجة إلى موضعية

المعطيات: إشارة بحدثٍ قصير عند لحظة محدّدة. الحل: الخطوة 1: FFT تخبر «أيّ تردّد» ولا تخبر «متى». الخطوة 2: مويجات/STFT تجيب عن الاثنين (الفصل 52). النتيجة: حدودُ فوريه المتّصل. الربط بالذكاء الاصطناعي: محوّلات الصوت تعالج الزمن صراحةً لهذا السبب.

مثال (51.6-15): التطبيق في إزالة الضجيج العمليّة

المعطيات: تسجيلٌ فيه طنين 50 Hz (شبكة الكهرباء). الحل: الخطوة 1: نجد القمّة في الطيف، ونصفّر خليّتها

notch) .(filter النتيجة: إزالةٌ دقيقة. الربط بالذكاء الاصطناعي: ترشيحٌ موجّه بالمشكلة قبل التعلّم.

أخطاء شائعة

١. **استخدام DFT للالتفاف بلا تهيئة صفرية:** التفافٌ دوري خاطئ.

٢. **تجاهل التسرّب في تفسير الطيف:** ذيل النافذة لا الإشارة.

٣. **الظنّ أن نافذة واحدة تصلح لكلّ مهمة:** المفاضلة ثابتة.

٤. **نسيان أن القطع الحادّ في التردّد يولّد رنيناً:** (غيبس في الزمن).

٥. **الخلط بين التفاف خطّي ودوري:** فرقٌ في الطول لا في الصيغة.

تمهيد استفهامي

إشارةٌ عشوائية — ضجيج، أو بورصة، أو إشارة دماغ. لا معاملات فوريه ثابتة لها، لأنّها لا تتكرّر. فما «طيفها»؟

الجواب: طيف **القدرة**، المعرّف من الارتباط الذاتي لا من الإشارة نفسها. ومبرهنة فينر–خينتشين تقول إنّ الاثنين وجهان لشيء واحد: **طيف القدرة = تحويل فوريه للارتباط الذاتي.** فالضجيج الأبيض (لا ارتباط بين لحظتين) له طيفٌ ثابت؛ والضجيج «الوردي» (ارتباط بطيء) له طيف $1/f$.

وهذا يفتح باباً واسعاً في التعلّم: تبييضُ الميزات (جعل طيفها ثابتاً)، وتقديرُ الارتباط الزمني للسلاسل، وفهمُ أنّ الطبيعة تختار غالباً أطيافاً $1/f$ — وهو ما يجعل العالم «متوقّعاً بما يكفي» لنتعلّم منه.

صياغة رسمية

$$R_x(\tau) = \mathbb{E}\big[x(t)\overline{x(t-\tau)}\big], \qquad \text{القدرة} = R_x(0) = \mathbb{E}|x|^2 \tag{1.7.51}$$

$$S_x(\omega) = \mathcal{F}\{R_x\}(\omega) = \int R_x(\tau) e^{-i\omega\tau} d\tau \quad \text{(فينر–خينتشين)} \tag{2.7.51}$$

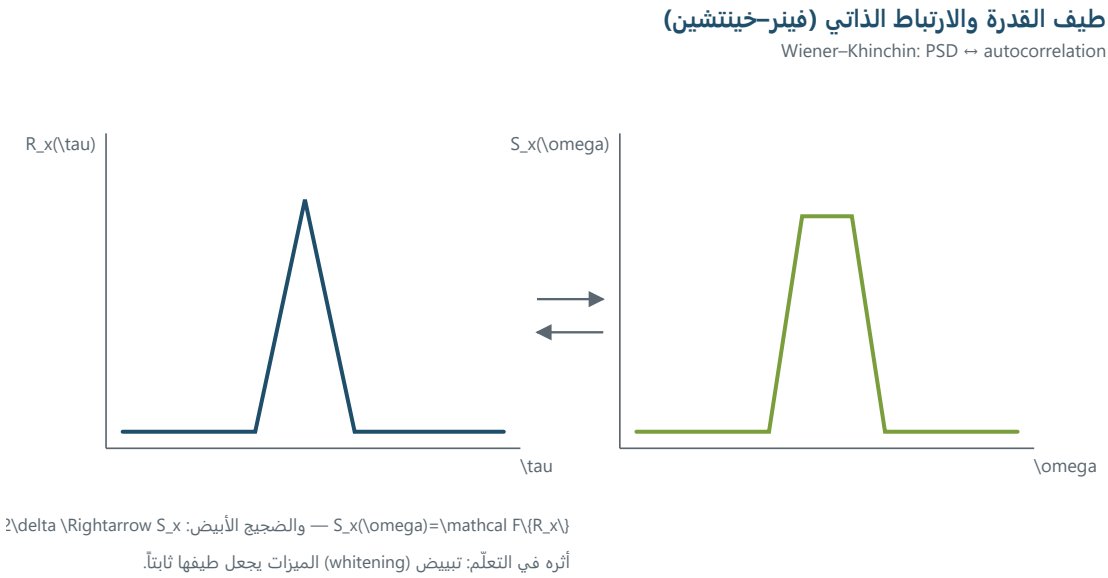
$$R_x(\tau) = \sigma^2 \delta(\tau) \;\Rightarrow\; S_x(\omega) = \sigma^2 \text{ ثابت} \quad \text{ضجيج أبيض:} \tag{3.7.51}$$

$$1/f \text{ ضجيج}: \; S_x(\omega) \propto \frac{1}{|\omega|^{\alpha}}, \qquad \alpha \approx 1 \tag{4.7.51}$$

$$\text{تقدير عملي (periodogram)}: \hat{S}[k] = \frac{1}{N}|X[k]|^2 \tag{5.7.51}$$

جدول الرموز

الرمز	المعنى	ملاحظة
$R_x(\tau)$	الارتباط الذاتي	يقيس «ذاكرة» الإشارة
$S_x(\omega)$	طيف القدرة (PSD)	توزيع القدرة على التردّد
σ^2	قدرة الضجيج الأبيض	ثابتة على كلّ الترددات
α	أُسّ الطيف $1/f^{\alpha}$	0 أبيض، 1 وردي، 2 بني
periodogram	مقدّر الطيف	متذبذب؛ يحتاج متوسطاً (Welch)



شكل ٦٠٥١: *
طيف القدرة والارتباط الذاتي بحسب فينر-خينتشين

برهان (مخطط)

١. **(2.7.51)** نكتب $R_x(\tau)$ كمعدّل زمني، ونطبّق التحويل، ونبدّل التكاملات $\Rightarrow |X_T(\omega)|^2/T \Rightarrow$ في النهاية $S_x = \lim \frac{1}{T}\mathbb{E}|X_T|^2$.

٢. **(3.7.51)** ارتباطُ الدلتا تحويلُه ثابت $\Rightarrow$ طيفٌ مسطّح (ومنه الاسم «أبيض» قياساً على الضوء).

٣. **(5.7.51)** من تعريف الطيف كنهاية لمربّع المطال مقسوماً على الزمن.

٤. **(Welch)** للتقليل من تباين المقدّر: نقسّم إلى مقاطع متداخلة وناخذ المتوسط. ■

شروط الصحّة: المبرهنة للإشارات العشوائية الثابتة (wide-sense stationary) و periodogram مقدّرٌ متحيّز ومتذبذب، تحسينُه بالمتوسط أو النوافذ.

أمثلة محلولة (15)

مثال (51.7-1): طيف ضجيج أبيض

المعطيات: $R_x(\tau) = \sigma^2\delta(\tau)$. الحل: الخطوة 1: $S_x = \sigma^2$ ثابت على كلّ الترددات. النتيجة: كلّ الترددات بقدر متساوٍ. الربط بالذكاء الاصطناعي: ضجيجُ التهيئة في الشبكات يُنمذج أبيض غالباً.

مثال (51.7-2): طيف إشارة جيبية + ضجيج

المعطيات: نغمة نقيّة + ضجيج أبيض. الحل: الخطوة 1: S_x = قاعدة ثابتة (ضجيج) + نبضتان (نغمة). النتيجة: الطيف يفصل المكوّنين. الربط بالذكاء الاصطناعي: فصلُ الإشارة عن الضجيج بالمجال الطيفي.

مثال (51.7-3): تقدير PSD عملياً

المعطيات: $N = 4096$ عيّنة من تسجيل. الحل: الخطوة 1: نقسّم إلى 8 مقاطع بـHann، ونحسب $\frac{1}{N}|X_k|^2$ لكلّ، ثم المتوسط (Welch). النتيجة: طيفٌ أقلّ تذبذباً. الربط بالذكاء الاصطناعي: المتوسط يقلّل التباين — كما في 7.49.

مثال (51.7-4): زمن الارتباط من الطيف

المعطيات: طيفٌ منخفض التمرير بعرض B. الحل: الخطوة 1: زمن الارتباط $\tau_c \approx 1/B$ ⇒ طيف ضيّق = ذاكرة طويلة. النتيجة: علاقةٌ عكسية ثابتة. الربط بالذكاء الاصطناعي: «طول الذاكرة» في SSM مرتبطٌ بعرض الطيف (7.53).

مثال (51.7-5): $1/f$ في الطبيعة

المعطيات: إشارات قلبية، وموسيقى، وبورصة. الحل: الخطوة 1: طيفها $1/f$ $\propto$ على مدى واسع ⇒ توازن بين الانتظام والمفاجأة. النتيجة: بنيةٌ قابلة للتعلّم. الربط بالذكاء الاصطناعي: لو كانت بيضاء لما تعلّمنا؛ ولو كانت بنية اللون لكانت متوقّعة تماماً.

مثال (51.7-6): تبييض الإشارة

المعطيات: إشارة بطيف هابط. الحل: الخطوة 1: نقسّم الطيف على $\sqrt{S_x}$ ⇒ طيفٌ ثابت ⇒ مكوّنات غير مترابطة. النتيجة: تبييض = إزالة ارتباط. الربط بالذكاء الاصطناعي: PCA/whitening يقابل هذا تماماً في فضاء الميزات.

مثال (51.7-7): كشف دورية في الضجيج

المعطيات: تسجيلٌ ضجيجي فيه دورة خفيّة. الحل: الخطوة 1: نحسب PSD ⇒ قمّة صغيرة فوق القاعدة تكشف الدورة. النتيجة: كشفٌ بمجال التردّد لا الزمن. الربط بالذكاء الاصطناعي: كشفُ الشذوذ بالطيف في مراقبة الآلات.

مثال (51.7-8): مقارنة مقدّرات

المعطيات: periodogram مقابل Welch. الحل: الخطوة 1: الأول تباينه كبير (لا يتقارب بزيادة N)؛ والثاني تباينه $\propto 1/$عدد المقاطع. النتيجة: Welch مفضّل عملياً. الربط بالذكاء الاصطناعي: المتوسط يقلّل التباين بلا تغيير التحيز.

مثال (51.7-9): قدرة الإشارة من الطيف

المعطيات: S_x معلوم. الحل: الخطوة 1: القدرة $R_x(0) = \frac{1}{2\pi}\int S_x(\omega)d\omega$. النتيجة: مساحة الطيف = القدرة. الربط بالذكاء الاصطناعي: مقياسُ طاقة التمثيلات في الشبكات.

مثال (51.7-10): التنبؤ من الارتباط

المعطيات: $R_x(\tau)$ يتلاشى بسرعة. الحل: الخطوة 1: القيم المتتالية شبه مستقلة ⇒ التنبؤ صعب. النتيجة: قابلية التنبؤ مرتبطة بزمن الارتباط. الربط بالذكاء الاصطناعي: حدودُ التنبؤ في السلاسل الزمنية (الفصل 19).

مثال (51.7-11): نقل الضجيج عبر مرشّح

المعطيات: ضجيج أبيض عبر مرشّح H. الحل: الخطوة 1: $S_y = |H|^2 S_x = |H|^2\sigma^2$ ⇒ المرشّح «يلوّن» الضجيج. النتيجة: تشكيلُ الطيف بالترشيح. الربط بالذكاء الاصطناعي: الطبقات تعيد تشكيل طيف التمثيلات.

مثال (51.7-12): طيف التدرّجات في التدريب

المعطيات: سلسلة تدرّجات عبر الخطوات. الحل: الخطوة 1: طيفٌ منخفض ⇒ تدرّجات متّسقة؛ طيفٌ عالٍ ⇒ تذبذب. النتيجة: تشخيصُ التدريب بالطيف. الربط بالذكاء الاصطناعي: أثرُ حجم الدفعة على «لون» ضجيج التدرّج.

مثال (51.7-13): تقدير عرض النطاق من PSD

المعطيات: طيفٌ يهبط 3 dB عند 5 kHz. الحل: الخطوة 1: هذا تعريفُ عرض النطاق العملي ⇒ نختار $f_s > 10$ kHz. النتيجة: قرارُ العيّنة من PSD. الربط بالذكاء الاصطناعي: قياسٌ ثم تصميم.

مثال (14-7.51): ارتباط مكاني في الصور

المعطيات: صورة طبيعية. الحل: الخطوة 1: طيفُ قدرتها $1/f^2$ $\propto$ تقريباً $\Rightarrow$ ارتباطٌ قوي بين البكسلات المتجاورة. النتيجة: مبرّرُ ضغط الصور (ارتباط قابل للاستغلال). الربط بالذكاء الاصطناعي: الارتباط المكاني هو ما تتعلّمه CNN.

مثال (15-7.51): لماذا يعمل الالتفاف في الشبكات؟

المعطيات: بياناتٌ ذات ارتباط محلي قوي (صور/صوت). الحل: الخطوة 1: الارتباط المحلي = طيفٌ مركّز $\Rightarrow$ مرشّحات موضعية تكفي. النتيجة: كفاءة الالتفاف مبرّرة إحصائيّاً. الربط بالذكاء الاصطناعي: الاستقراء المكاني في CNN مبرَّرٌ بـPSD الطبيعي.

أخطاء شائعة

١. **تطبيق PSD على إشارة غير ثابتة:** النتيجة غير ذات معنى.

٢. **الاعتماد على periodogram واحد:** تباينه لا يزول بزيادة N.

٣. **الخلط بين الطيف والقدرة:** $|X|$ مقابل $|X|^2$.

٤. **نسيان الدور في** $S_y = |H|^2 S_x$: المربع لا القيمة.

٥. **تجاهل الدور/النافذة في التقدير:** يضيف تحيّزاً وتسرّباً.

تمهيد استفهامي

لماذا تتعلّم الشبكةُ «الشكل العام» للدالة خلال عشرات الخطوات، ثم تحتاج آلافاً لضبط التفاصيل؟ ولماذا تفشل في تقريب الدوالّ سريعة التذبذب؟ ولماذا يعمل استبدالُ طبقة الانتباه بمزجٍ فوريه (FNet) بشكلٍ معقول؟

كلّها أسئلةٌ عن **التحيّز الطيفي** (spectral bias): الشبكات العصبية — بتهيئتها المعتادة وتدرّجها — تتعلّم المكوّنات منخفضة التردّد أولاً وبسرعة، والمكوّنات عالية التردّد آخراً وببطء. هذه الملاحظة التجريبية لها تفسيرٌ نظري عبر نواة NTK (الفصل 40): قيم NTK الذاتية الكبرى تقابل المكوّنات الناعمة، وديناميكية التدرّج تتعلّمها أولاً بهيئةٍ أُسّيّة.

وهذا يفتح باب تصميم: إن كانت مهمتك عالية التردّد (تفاصيل صور، أو حدود حادّة)، فلا تكتفِ بالشبكة العادية — أعطها ميزاتٍ طيفية صريحة.

صياغة رسمية

$$|f_t - f^\star|_k \approx e^{-\lambda_k t}|f_0 - f^\star|_k, \quad \lambda_k \searrow \text{ مع التردّد} \qquad \text{ديناميكية التعلّم في فضاء NTK:} \tag{1.8.51}$$

$$t_k \approx \frac{1}{\lambda_k}\log\frac{|c_k(0)|}{\varepsilon} \qquad : k \text{ زمن تعلّم المكوّن} \tag{2.8.51}$$

$$\phi(x) = \big[\cos(Bx),\ \sin(Bx)\big],\quad B \sim \mathcal{N}(0, \sigma^2) \qquad (3.8.51)$$ ميزات فوريه العشوائية (RFF):

$$y = \mathcal{F}^{-1}\big(R \cdot \mathcal{F}(x)\big) \Rightarrow O(n \log n) \qquad (4.8.51)$$ طبقة مزج طيفي (FNet): تكلفة بلا معاملات

جدول الرموز

الرمز	المعنى	ملاحظة
λ_k	القيمة الذاتية k لـNTK	كبراها = منخفض التردّد
t_k	زمن تعلّم المكوّن	يعتمد على λ_k عكسياً
B	مصفوفة ترددات عشوائية	عرض نطاقها σ يضبط النعومة
RFF	ميزات فوريه عشوائية	تقريب نواة ثابت (Bochner)
R	مصفوفة المزج الطيفي	متعلَّمة أو ثابتة

برهان (مخطط)

١. **(1.8.51)** في النظام الخطّي المكافئ لـNTK: $\dot{f} = -\Theta(f - y)$؛ ونفكّك على قاعدة NTK الذاتية ⇒ كلّ مكوّن يتضائل أُسّيّاً بمعدّل λ_k (الفصل 40).

٢. **(2.8.51)** بحلّ الزمن اللازم للوصول إلى ε.

٣. **(3.8.51)** بمبرهنة بوخنر: النواة الثابتة تحويلُ فوريه لتوزيع؛ وتقديره بعيّنات ⇒ RFF.

٤. **(4.8.51)** مزجُ الرموز بـFFT يحقّق اتصالاً عالمياً بتكلفة لوغاريتمية بلا تعلّم للمزج. ■

شروط الصحّة: (1.8.51) في نظام NTK (شبكة عريضة، خطوة صغيرة)؛ وللشبكات العميقة الفعلية هو توجيهٌ قوي لا حكم دقيق. وσ في RFF يضبط النعومة: كبير ⇒ ترددات عالية ⇒ تعقيد أكبر وتذبذب أكثر.

أمثلة محلولة (15)

مثال (1-8.51): لماذا النعومة أولاً؟

المعطيات: هدف = مجموع نغمتين بتردّدين 1 و20. الحل: الخطوة 1: المكوّن 1 له λ أكبر ⇒ يتعلّم خلال عشرات الخطوات. الخطوة 2: المكوّن 20 يحتاج أضعافاً مضاعفة من الزمن. النتيجة: منحنى تعلّم «متدرّج الطيف». الربط بالذكاء الاصطناعي: تفسيرُ منحنى الخسارة الشهير: هبوطٌ سريع ثم ذيلٌ طويل.

مثال (2-8.51): فشل تقريب تردّد عالٍ

المعطيات: شبكة MLP تقرّب $\sin(50x)$. الحل: الخطوة 1: التردّد العالي خارج نطاق التعلّم السريع ⇒ احتاج زمنًا طويلاً أو لم ينجح. الخطوة 2: بإضافة ميزات فوريه: تنجح خلال خطوات قليلة. النتيجة: التمثيل يغيّر قابلية التعلّم. الربط بالذكاء الاصطناعي: مبرّرُ ترميز الموضع في NeRF والمحوّلات.

مثال (51.8-3): RFF لتقريب نواة غاوسية

المعطيات: نواة غاوسية بعرض ℓ. الحل: الخطوة 1: توزيع الترددات $\mathcal{N}(0, 1/\ell^2) \Rightarrow D$ عيّنة تعطي تقريباً بخطأ $\sim 1/\sqrt{D}$. الخطوة 2: اختيار D من ميزانية الخطأ (كما في 13-8.49). النتيجة: تحويلٌ من نواة لانهائية إلى ميزات منتهية. الربط بالذكاء الاصطناعي: تقنيةٌ أساسية في الآلات النووية السريعة.

مثال (51.8-4): اختيار عرض نطاق RFF

المعطيات: σ صغير جدّاً. الحل: الخطوة 1: الميزات ناعمة $\Rightarrow$ النموذج لا يستطيع تمثيل التفاصيل $\Rightarrow$ تحيّز كبير. الخطوة 2: وσ كبير $\Rightarrow$ تباين كبير وتذبذب. النتيجة: σ معاملُ نعومة. الربط بالذكاء الاصطناعي: نظيرُ اختيار عرض النواة في المرشّحات/SVM.

مثال (51.8-5): FNet بديلاً عن الانتباه

المعطيات: طبقة انتباه بـ$n = 4096$. الحل: الخطوة 1: الانتباه $O(n^2 d)$، والمزج الطيفي $O(n \log n\, d)$. الخطوة 2: الدقة تنخفض قليلاً (1–3 نقاط) مقابل تسريع كبير. النتيجة: مقايضةٌ مدروسة. الربط بالذكاء الاصطناعي: مبرّرُ البدائل الطيفية للمحوّلات (الفصل 53).

مثال (51.8-6): الترميز الموضعي الجيبي

المعطيات: ترميز المحوّلات $\sin(\omega_k x)$ بترددات هندسية. الحل: الخطوة 1: يوفّر ترددات جاهزة على مقاييس متعدّدة $\Rightarrow$ يخفف التحيّز الطيفي. النتيجة: استقراءٌ مدمج في المدخلات. الربط بالذكاء الاصطناعي: نفس فكرة RFF لكن ثابتة ومنظّمة.

مثال (51.8-7): التحيّز الطيفي والانتظام

المعطيات: تدريبٌ بلا تنظيم على دالة ضجيجية. الحل: الخطوة 1: الترددات المنخفضة تُتعلّم أولاً، والضجيج عالي التردّد يُتعلّم أخيراً. الخطوة 2: التوقّف المبكر (early stopping) يعمل «مرشّحاً منخفض التمرير». النتيجة: تنظيمٌ زمني بلا معاملات إضافية. الربط بالذكاء الاصطناعي: تفسيرُ التوقّف المبكر من الزاوية الطيفية.

مثال (51.8-8): الطيف وتقطير المعاملات (LoRA)

المعطيات: تحديث برتبة منخفضة $\Delta W = BA$. الحل: الخطوة 1: الرتبة المنخفضة = اقتطاع طيفي $\Rightarrow$ نحتفظ بالمكوّنات المهيمنة. النتيجة: ضغطُ التحديث بمبرّر رياضي. الربط بالذكاء الاصطناعي: LoRA تطبيقٌ لـ(3.8.50) على مصفوفات الأوزان.

مثال (8.51-9): تهيئة الأوزان والطيف

المعطيات: تهيئةٌ بتباين كبير. الحل: الخطوة 1: تُضخّم الترددات العالية ⇒ تدريبٌ غير مستقر. الخطوة 2: تهيئة مناسبة (He/Glorot) تبقي الطيف متوازناً. النتيجة: استقرارٌ من ضبط الطيف الابتدائي. الربط بالذكاء الاصطناعي: التهيئة = تصميمُ مرشّح ابتدائي.

مثال (8.51-10): الخسارة في مجال التردّد

المعطيات: تدريب شبكة صور بـMSE في الزمن/المكان. الحل: الخطوة 1: MSE يعاقب كلّ الترددات بالتساوي؛ والضجيج عالِ التردّد يستهلك قدرة النموذج. الخطوة 2: خسارةٌ طيفية تُوزن الترددات ⇒ نتائج أوضح. النتيجة: تصميمُ الخسارة مسألةُ طيف. الربط بالذكاء الاصطناعي: losses طيفية في الصور والصوت (focal-in-frequency).

مثال (8.51-11): التحيّز الطيفي في التوليد

المعطيات: نموذج انتشار يولّد صوراً. الحل: الخطوة 1: يولّد البنية الخشنة أولاً (تردّد منخفض) ثم التفاصيل (عالٍ) — ترتيبٌ طيفي في خطوات إزالة الضجيج. النتيجة: تفسيرُ سلوك نماذج الانتشار. الربط بالذكاء الاصطناعي: يربط الفصل 41 بهذا الفصل.

مثال (8.51-12): قياس التحيّز الطيفي عملياً

المعطيات: نريد قياس سرعة تعلّم كلّ تردّد. الحل: الخطوة 1: نحسب خطأ النموذج في كلّ خليّة تردّد عبر الزمن ⇒ منحنيات لكلّ تردّد. النتيجة: أداة تشخيص قابلة للقياس. الربط بالذكاء الاصطناعي: تحليلٌ طيفي لتدريب الشبكات — مجال بحث نشط.

مثال (8.51-13): الالتفاف بـFFT في الشبكات الكبيرة

المعطيات: التفاف بنواة كبيرة جدّاً (64×64). الحل: الخطوة 1: FFT أرخص نظرياً؛ لكن على GPU قد يخسر بسبب النقل. النتيجة: القرار عملي لا نظري. الربط بالذكاء الاصطناعي: التعقيد النظري ≠ الأداء الفعلي (3.51-14).

مثال (8.51-14): التعلّم المنهجي (curriculum)

المعطيات: تقديم أمثلة «سهلة» (منخفضة التردّد) أولاً. الحل: الخطوة 1: يوافق التحيّز الطيفي للشبكة ⇒ تقارب أسرع وأفضل. النتيجة: منهجيةٌ مدعومة بالتحليل الطيفي. الربط بالذكاء الاصطناعي: تصميمُ المنهج من طيف البيانات.

مثال (15-8.51): حدود الاستقراء الطيفي

المعطيات: مهمةٌ تتطلّب تمثيلاً غير دوري وموضعياً جدّاً. الحل: الخطوة 1: الأسس الطيفية العالمية أقل كفاءة ⇒ الموجات أو المرشّحات الموضعية أصلح. النتيجة: لا تمثيل عالمي واحد. الربط بالذكاء الاصطناعي: الجسر إلى الفصل 52 (تحليل زمني-ترددي موضعي).

أخطاء شائعة

١. **الظنّ أن التحيّز الطيفي عيبٌ يمكن إلغاؤه:** هو خاصية بنيوية تُدار لا تُلغى.

٢. **زيادة RFF بلا حساب:** الخطأ $1/\sqrt{D}$ فقط — عائد متناقص.

٣. **تجاهل أن التوقّف المبكر مرشّح منخفض التمرير:** قد يفقد التفاصيل المطلوبة.

٤. **استخدام FFT للالتفاف دائماً:** القرار بالقياس على العتاد.

٥. **الخلط بين التحيّز الطيفي وسعة النموذج:** الأول عن الديناميكية والثاني عن القدرة.

تمارين (30)

مستوى أول:

١. احسب تحويل فوريه للنبضة المستطيلة بعرض τ.

٢. احسب طيف $e^{-a|t|}$.

٣. بيّن أن $\mathcal{F}\{x'\} = i\omega X$ بالتجزئة.

٤. احسب DFT لـ$x = [1, 0, -1, 0]$ باليد.

٥. تحقّق من تماثل الطيف في (4).

٦. احسب Δf لـ$f_s = 8$ kHz و$N = 512$.

٧. نغمة 3 kHz: ما أقلّ f_s آمن؟

٨. احسب التردّد المرئي لـ$f = 1500$ Hz بعيّنة 1000 Hz.

٩. احسب طاقة $|X|^2$ لإشارة $[1, 1, 1, 1]$ وتحقّق ببارسيفال.

١٠. اكتب نافذة Hann لـ$N = 8$ رقمياً.

مستوى ثان:

١. برهن (1.6.51) خطوةً بخطوة (الضرب ↔ الالتفاف).

٢. بيّن أن الالتفاف بالدوران (circular) يظهر بلا تهيئة صفرية.

٣. اشترط الطول الأدنى لتحويل التفاف خطّي إلى دوري صحيح.

٤. اشتقّ صيغة إعادة البناء (1.4.51) من الترشيح المثالي.

٥. برهن فينر–خينتشين بمخطط (استخدم حدّ متوسط الزمن).

٦. احسب طيف القدرة لعملية AR(1): $x_n = \rho x_{n-1} + \varepsilon_n$.

٧. قارن بين نافذتي Hann والمستطيل من حيث الفصوص.

٨. احسب نسبة التشويه لإشارة طاقتها 15٪ فوق نيكويست.

٩. بيّن أن zero-padding لا يحسّن الدقة الحقيقية.

١٠. اربط بين (1.8.51) ومنحنى الخسارة في تجربة تدريب واقعية.

مستوى ثالث:

١. صمّم خطوة preprocessing لصوت 48 kHz تُنتج 80 log-mel قناة (اذكر الأرقام).

٢. صورةٌ فيها moiré: اقترح علاجين واذكر المبرّر الطيفي.

٣. شبكة لا تتعلّم التفاصيل: شخص المشكلة طيفيّاً واقترح حلّين.

٤. متى تختار التفافاً مباشراً ومتى FFT؟ اذكر قاعدة كمّية تقريبية.

٥. اشرح كيف يعمل «anti-aliased pooling» ولماذا يفيد.

٦. قدّر زمن الارتباط من عرض نطاق طيف معلوم، وعلّق على أثره في التنبؤ.

٧. احسب ميزانية RFF لخطأ تقريب نواة info معلوم.

٨. قارن بين FNet والانتباه الكامل من حيث التكلفة والدقة.

٩. صغ «تصميم تجربة جمع بيانات» بوصفه مسألة نيكويست.

١٠. اربط بين التحيّز الطيفي وظاهرة الهبوط المزدوج (double descent) إن استطعت.

ملخص الفصل

النظرية	الصيغة المحوريّة	الدرس العملي
تحويل فوريه	$X(\omega) = \int x e^{-i\omega t}$	الالتفاف ضرب، والتفاضل $i\omega$
DFT وFFT	$O(N^2)$ بدل $O(N \log N)$	مكّنت معالجة الإشارة الرقمية
نيكويست–شانون	$f_s > 2B$ وإعادة بناء بـsinc	لماذا 1.44 kHz
التشويه الطيفي	$f_{\text{مرئي}} = \|f - k f_s\|$	رشّح قبل أن تختزل
الالتفاف والنوافذ	$h * x \rightleftharpoons HX$	التسرّب مفاضلة لا خطأ
طيف القدرة	$S_x = \mathcal{F}\{R_x\}$	الأبيض ثابت، والطبيعي $1/f$
الطيف في التعلّم	λ_k تهبط مع التردّد	النعومة تُتعلّم أولاً

الجسر إلى الفصل 52: فوريه المتّصل يخبرك «أيّ الترددّات موجودة» لكن لا يخبرك «متى». فكيف نحصل على الاثنين معاً؟ هذا هو التحليل الزمني-الترددي: STFT، ثم المويجات التي تعطي شبكةً متعدّدة المقاييس بدل شبكة ثابتة.

جدول الرموز (فهرس الفصل)

الرمز	المعنى
$X(\omega)$, $X[k]$	الطيف المتّصل والمنفصل
f_s, T_s, B	معدّل العيّنة، زمنها، عرض النطاق
W_N	جذر الوحدة الأولي $e^{-2\pi i/N}$
sinc	نواة إعادة البناء
R_x, S_x	الارتباط الذاتي وطيف القدرة
$h * x$, $H \cdot X$	الالتفاف وضرب الطيف
λ_k, ϕ	طيف NTK وميزات فوريه العشوائية

نهاية الفصل الحادي والخمسين — ومنه نعبر إلى التحليل الزمني-الترددي والمويجات في الفصل الثاني والخمسين.

التحليل الزمني-الترددي والمويجات

الشعار: «فوريه يخبرك أيّ نغمةٍ في المقطوعة، والمويجة تخبرك متى عزفها العازف — ولا يمكنك أن تعرف الاثنين بلا حدود.»

تمهيد قصصي للفصل: أين النغمة في الزمن؟

استمع إلى مقطوعة بيانو: فوريه يعطيك طيفاً رائعاً يقول «فيها دو، مي، صول» — لكنّه لا يقول إنّ «الدو» عُزفت في الثانية الأولى و«المي» في الخامسة. الطيف ينسى الزمن تماماً: لو عزفت المقطوعة **بالعكس** لكان طيف مقدارها مطابقاً تقريباً!

فكيف نرسم «خريطة» تجمع الزمن والتردّد؟ الفكرة الأولى بسيطة: **قسّم الإشارة نوافذ قصيرة، وحلّل كلّ نافذة بفوريه** — هذا تحويل فوريه قصير الزمن، (STFT) ونتاجُه المخطوط الطيفي (spectrogram) الذي تراه في كلّ برامج الصوت. لكنّه يصطدم بحائط: النافذة الواحدة بدقة واحدة، فإمّا زمنٌ دقيق وتردّد غليظ، أو العكس — **مبدأ الريبة** لا يسمح بالاثنين.

والفكرة الثانية أذكى: لا تستخدم نافذة واحدة، بل **مويجة** تتقلّص وتتمدّد. عند التردّدات العالية نافذة ضيّقة (دقّة زمنية)، وعند المنخفضة نافذة واسعة (دقّة ترددية). هذه هي المويجات — أشبهُ بعدسةٍ مُقَرِّبة تتكيّف مع المقياس، ولهذا تفوّقت على فوريه في ضغط الصور (JPEG2000) وإزالة الضجيج وتحليل الاهتزازات.

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. صياغة **مبدأ الريبة** والتعامل مع مفاضلة الزمن-التردّد كمّيّاً.

٢. حساب **STFT** وقراءة المخطوط الطيفي واختيار النافذة والقفزة.

٣. تعريف **المويجة الأُمّ** والتحويل المويجي المستمر (CWT) وقراءة المقياس تردّداً.

٤. بناء **DWT** ببنك مرشّحات، والتحقق من شروط الكمال، وحساب التعقيد $O(N)$.

٥. استخدام **العتبة** (thresholding) لإزالة الضجيج وتقدير الخطأ.

٦. فهم **توزيع فيغنر–فيل** وحدوده المتقاطعة وعلاجاتها.

٧. توظيف **تحويل التشتّت** (scattering) بوصفه تمثيلاً ثابتاً بلا تعلّم.

المتطلبات المسبقة

الفصل 51، والفصل 49 (العموديّة وبارسيفال)، والفصل 2 (الفضاءات الداخلية).

خريطة الفصل

القسم	القانون/النظرية	عدد الأمثلة المحلولة
1.52	لماذا لا يكفي فوريه: المفردات	—
2.52	مبدأ الريبة وحدود الدقة المزدوجة	15
3.52	STFT والمخطوط الطيفي	15
4.52	المويجات والتحويل المويجي المستمر	15
5.52	التحويل المنفصل DWT والتحليل متعدد الدقة	15
6.52	إزالة الضجيج بالعتبة	15
7.52	توزيع فيغنر–فيل وحدوده المتقاطعة	15
8.52	تحويل التشتّت والتمثيلات الثابتة	15
9.52	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

Heisenberg · Resolution Time–Frequency · Spectrogram · Transform Fourier Short-Time · Transform Wavelet Continuous · Wavelet Mother · Wavelet · Transform Gabor · Uncertainty · Downsampling · Analysis Multi-Resolution · Bank Filter · Transform Wavelet Discrete · Scale Transform Scattering · Cross-terms · Distribution Wigner–Ville · Denoising · Thresholding

طيفٌ واحد للإشارة كلها يعني فقدان الموضع الزمني. نريد تمثيلاً $T[x](t,\omega)$:

$$X(\omega) \;\longrightarrow\; \text{مويجات/STFT}: T[x](t,\omega) \quad \text{«كم من التردّد } \omega \text{ عند اللحظة } t \text{»} \qquad (1.1.52)$$ فوريه:

الرمز	المعنى	ملاحظة
$w[n]$	نافذة التحليل	تحدّد المفاضلة
H	قفزة النافذة (hop)	التحصيل الزمني
a	مقياس المويجة	عكس التردّد تقريباً
b	إزاحة المويجة	الموضع الزمني
ψ	المويجة الأُمّ	شرطها $\int \psi = 0$
$cA,\ cD$	التقريبات والتفاصيل	خراج DWT

الشرط الجوهري للمويجة: $\int \psi(t)dt = 0$ — أي أنّها «موجة صغيرة» تتأرجح حول الصفر، ومنه اسمها (wavelet). وهذا يجعلها حسّاسة للتغيّرات الموضعية بدل المكوّن المستمر.

تمهيد استفهامي

هل يمكن أن نعرف تردّد الإشارة بدقة اختيارية **ولحظة حدوثها بدقة اختيارية** في الوقت نفسه؟ الجواب — بصيغة رياضية قاطعة — **لا**. وهذا ليس عجزاً في أدواتنا بل خاصيةٌ بنيوية للإشارات: تماماً كما في ميكانيكا الكم حيث لا يمكن تحديد الموضع والزخم معاً، كذلك هنا: ضيقٌ في الزمن يعني انتشاراً في التردّد والعكس.

هذه الحقيقة ليست عائقاً بل **دليل تصميم**: كلّ خوارزمية تحليل زمني-ترددي هي اختيارٌ واعٍ لموضعك على هذا المربع. فSTFT تعطيك شبكةً ثابتة، والمويجات شبكةً متعدّدة المقاييس، وتوزيعات الطاقة (7.52) تحاول تجاوز الحدّ بثمنٍ آخر.

صياغة رسمية

ليكن $x(t)$ بمعيار واحد، و$\Delta_t^2 = \int (t-t_0)^2|x|^2 dt$ و$\Delta_\omega^2 = \frac{1}{2\pi}\int(\omega-\omega_0)^2|X|^2 d\omega$. فإنّ:

$$\Delta_t\,\Delta_\omega \;\geq\; \frac{1}{2} \qquad (1.2.52)$$

$$x(t) = \exp\Big(-\frac{(t-t_0)^2}{2\sigma^2} + i\omega_0 t\Big) \quad \text{والمساواة للغاوسي فقط:} \tag{2.2.52}$$

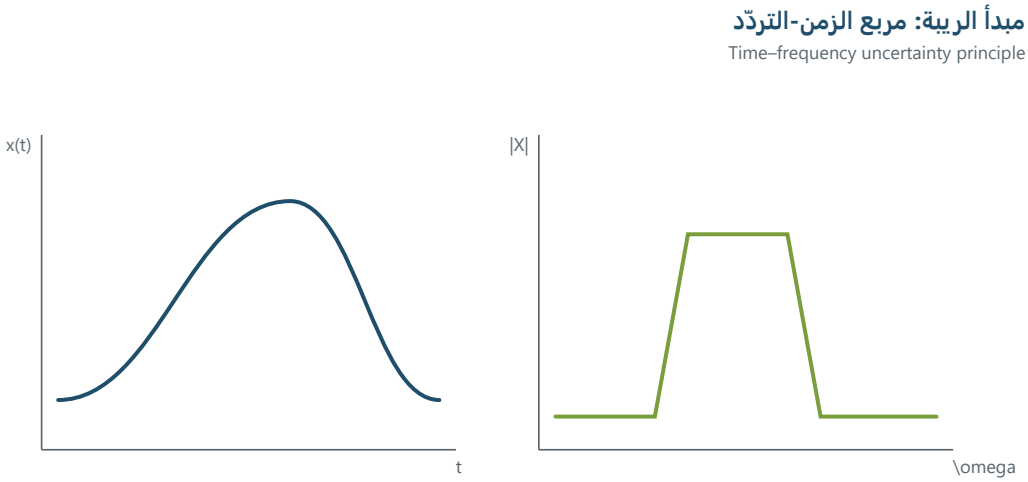
$$\Delta t \approx N, \quad \Delta f \approx \frac{f_s}{N}, \quad \Delta t \cdot \Delta f \approx f_s = \text{ثابت} \quad \text{في الصورة المنفصلة (STFT):} \tag{3.2.52}$$

(4.2.52)

لا يمكن لقاعدة غابور أن تكون موضعية جيداً ومتعمّدة في آن—مبرهنة بنديكت–تيان–فان (Balian–Low):

جدول الرموز

الرمز	المعنى	ملاحظة
Δ_t, Δ_ω	انتشارا الزمن والتردّد	جذّاءهما $\geq 1/2$
t_0, ω_0	مركزا الزمن والتردّد	المرجع في الحساب
σ	عرض الغاوسي	يضبط المفاضلة
N	طول النافذة المنفصلة	$\Delta t \cdot \Delta f = f_s$
غابور	نواة غاوسية معدّلة	تحقّق المساواة



شكل ١٠٥٢: *
مبدأ الريبة: العلاقة العكسية بين دقة الزمن ودقة التردد

برهان (مخطط)

١. **(1.2.52)** نستخدم متفاوتة كوشي–شفارتس على $\int |tx|^2 \cdot \int |\omega X|^2$ مع متطابقة $\langle tx, x' \rangle$ (تكامل بالتجزئة) $\Rightarrow$ الحدّ $1/2$.

٢. **(2.2.52)** شرط تساوي كوشي–شفارتس هو التناسب $x'(t) \propto (t-t_0)x(t) \Rightarrow$ الحلّ غاوسي معدّل.

٣. **(3.2.52)** من تعريف STFT: دقة التردّد f_s/N ودقة الزمن $N/f_s \Rightarrow$ الجداء ثابت 1 بالعيّنات.

٤. **(4.2.52)** نتيجة أعمق: لا وجود لقاعدة غابور «مثالية» (موضعية ومتعمّدة معاً). ■

شروط الصحّة: (1.2.52) للإشارات بمعيار واحد ومتلاشية عند الأطراف، والصيغة المنفصلة تقريبية (تعتمد على تعريف النافذة). والحدّ ليس عن الحساب بل عن التمثيل نفسه.

أمثلة محلولة (15)

مثال (1-2.52): نبضة قصيرة جدّاً

المعطيات: نبضة بعرض 1 ms. الحل: الخطوة 1: $\Delta_t \approx 10^{-3} \Rightarrow \Delta_\omega \geq 500$ rad/s $\Delta f \geq 80$ Hz. النتيجة: دقة التردّد محدودة بـ80 Hz مهما بلغت دقّة الحساب. الربط بالذكاء الاصطناعي: الأحداث القصيرة لا تُحدَّد ترددّاتها بدقة — قيدٌ فيزيائي.

مثال (2-2.52): نغمة طويلة

المعطيات: نغمة 440 Hz لمدة ثانية. الحل: الخطوة 1: دقة تردّد ممتازة (~ 1 Hz) لكن موضعها الزمني غامض. النتيجة: المفاضلة نفسها بالاتجاه الآخر. الربط بالذكاء الاصطناعي: لا يمكن كشف لحظة بداية النغمة بدقة مع دقة ترددّية عالية.

مثال (3-2.52): الغاوسي حقّق الحدّ

المعطيات: نبضة غاوسية بعرض σ. الحل: الخطوة 1: $\Delta_t\Delta_\omega = 1/2$ بالضبط $\Rightarrow$ الأمثل. النتيجة: الغاوسي «أذكى» نافذة ممكنة. الربط بالذكاء الاصطناعي: لهذا تُستخدم نواة غاوس في كثير من المرشّحات.

مثال (4-2.52): مفاضلة في STFT عمليّة

المعطيات: $f_s = 16$ kHz، نافذة 512. الحل: الخطوة 1: $\Delta t = 32$ ms و$\Delta f = 31.25$ Hz $\Rightarrow$ الجداء 1000 = عدد العيّنات ✓. النتيجة: زيادة النافذة تحسّن التردّد وتُضعف الزمن. الربط بالذكاء الاصطناعي: اختيارُ حجم النافذة قرارٌ مهمة.

مثال (5-2.52): كشف حدث قصير

المعطيات: نقرة بعرض 2 ms في تسجيل. الحل: الخطوة 1: نحتاج نافذة قصيرة (~ 4 ms $\Rightarrow$ دقة تردّد ضعيفة لكن الموضع واضح. النتيجة: النافذة القصيرة للأحداث السريعة. الربط بالذكاء الاصطناعي: كشفُ الأحداث النادرة يتطلّب تحليلاً موضعياً.

مثال (6-2.52): نغمتان متقاربتان

المعطيات: 1000 و1010 Hz معاً. الحل: الخطوة 1: نحتاج $\Delta f < 10$ Hz $\Rightarrow$ نافذة > 160 ms. الخطوة 2:

إذن لا نستطيع تمييز لحظاتهما بدقة أفضل من 160 ms. النتيجة: لا مفرّ. الربط بالذكاء الاصطناعي: مفاضلة دقة التمييز مقابل الاستجابة السريعة.

مثال (2.52-7): مبرهنة Balian–Low عملياً

المعطيات: نريد قاعدة زمنية-ترددية دقيقة ومتعمّدة. الحل: الخطوة 1: مستحيل رياضيّاً ⇒ نكتفي بتقريبات (مويجات متعامدة بتنازلات). النتيجة: لا قاعدة مثالية. الربط بالذكاء الاصطناعي: حدودُ التمثيلات تُدير تصميم النماذج لا العكس.

مثال (2.52-8): لماذا المويجات أفضل للقفزات

المعطيات: إشارة فيها قفزة عند لحظة محدّدة. الحل: الخطوة 1: القفزة عالية التردّد وموضعية تماماً ⇒ مويجة ضيّقة عند مقياس صغير تكفيها بمعامل واحد. الخطوة 2: فوريه يوزّعها على كلّ الترددات. النتيجة: كفاءةُ التمثيل بالمويجات. الربط بالذكاء الاصطناعي: المويجات أصلح للإشارات المتقطّعة (وJPEG2000 شاهد).

مثال (2.52-9): مربع الزمن-التردد في التصميم

المعطيات: نرسم مستطيلات بدقة $\Delta f \times \Delta t$. الحل: الخطوة 1: مساحة المستطيل ثابتة ⇒ نختار شكله بحسب المهمة. النتيجة: المويجات تعطي مستطيلات متغيّرة الشكل. الربط بالذكاء الاصطناعي: تكيّفُ المقياس ميزة المويجات الجوهريّة.

مثال (2.52-10): نافذة غاوسية في غابور

المعطيات: نافذة $\sigma = 5$ ms. الحل: الخطوة 1: $\Delta f \approx 1/(2\pi\sigma) \approx 32$ Hz. النتيجة: الحدّ الأدنى الممكن. الربط بالذكاء الاصطناعي: غابور مرجعُ الكفاءة في التحليل الزمني-الترددي.

مثال (2.52-11): التردّد الآني ومبدأ الريبة

المعطيات: إشارة تردّدها يتغيّر بسرعة (chirp). الحل: الخطوة 1: قياس التردّد الآني يحتاج نافذة؛ وكلّ نافذة تعطي متوسطاً ⇒ خطأ منهجي. النتيجة: التردّد الآني مفهومٌ تقريبي. الربط بالذكاء الاصطناعي: تقديرُ «التردّد اللحظي» في السلاسل المالية محدود بالقيد نفسه.

مثال (2.52-12): مقارنة تمثيلات

المعطيات: إشارة = نغمة طويلة + نقرة قصيرة. الحل: الخطوة 1: فوريه: ممتاز للنغمة، سيّئ للنقرة. الخطوة 2: STFT بنافذة واحدة: حل وسط لكليهما. الخطوة 3: مويجات: جيد للاثنين بمقاييس مختلفة. النتيجة: التمثيل متعدّد المقياس يتفوّق. الربط بالذكاء الاصطناعي: الهرميّة (multi-scale) مبدأٌ ناجح في الشبكات أيضاً

(FPN/U-Net).

مثال (2.52-13): مفاضلة في رسم spectrogram

المعطيات: نريد عرضاً واضحاً للصوت. الحل: الخطوة 1: نافذة قصيرة ⇒ خطوط زمنية واضحة وتردّدية ضبابية والعكس. النتيجة: إعدادات العرض قرارُ مفاضلة. الربط بالذكاء الاصطناعي: ميزات log-mel ترث هذه المفاضلة.

مثال (2.52-14): حدود دقة الكشف عن الشذوذ

المعطيات: شذوذٌ مدته 1 عيّنة في سلسلة. الحل: الخطوة 1: كشفه زمنياً ممكن؛ وتحديد «تردّده» غير ممكن. النتيجة: بعض الأسئلة بلا معنى رياضي. الربط بالذكاء الاصطناعي: صياغةُ السؤال جزءٌ من الحلّ.

مثال (2.52-15): مبدأ الريبة في تعلّم الآلة

المعطيات: نموذجٌ يجب أن يستجيب بسرعة ويصنّف بدقة. الحل: الخطوة 1: سرعة الاستجابة = نافذة قصيرة = معلومات أقل = دقة أقل. النتيجة: مفاضلة التأخير مقابل الدقة. الربط بالذكاء الاصطناعي: تصميمُ النظم الآنية يخضع للقيد نفسه.

أخطاء شائعة

١. **طلب دقة عالية في الزمن والتردّد معاً:** مستحيل رياضياً.

٢. **الظنّ أن المويجات تلغي مبدأ الريبة:** تعيد توزيعه على المقاييس.

٣. **نسيان أن النافذة تحدّد المفاضلة لا جودة الحساب.**

٤. **استخدام نافذة واحدة لكلّ المهام.**

٥. **تفسير «التردّد الآني» بلا ذكر النافذة:** بلا معنى.

تمهيد استفهامي

كيف تعمل برامج تحرير الصوت التي تريك «خريطة حرارية» للصوت؟ وكيف تعرف خوارزمية التعرّف على الكلام أنّ هذه «س» لا «ش»؟ الجواب: **المخطوط الطيفي** (spectrogram) — صورةٌ محورها الأفقي الزمن، والعمودي التردّد، واللون الشدّة. هذه الصورة هي التي غذّت عقوداً من أنظمة الصوت، وهي التي تغذّي اليوم الشبكات العصبية (log-mel).

والجميل أنّ فكرتها في منتهى البساطة: نافذة منزلقة + فوريه في كلّ موضع. وكلّ ما تعلّمناه في الفصل 51 يجتمع هنا: النافذة تحدّد التسرّب، والطول يحدّد الدقة، والقفزة تحدّد التحصيل الزمني — ثمّ نضيف اللوغاريتم ومقياس mel لنقترب من إدراك الأذن.

صياغة رسمية

$$X[m,k] = \sum_{n=0}^{N-1} x[n + mH]\, w[n]\, e^{-2\pi i k n / N} \tag{1.3.52}$$

المخطوط الطيفي: $S[m,k] = |X[m,k]|^2, \qquad \text{log-mel: } M[m,j] = \log\Big(\sum_k F_{jk} S[m,k]\Big)$ (2.3.52)

شرط إعادة البناء (OLA): $\sum_m w[n - mH] = 1 \ \forall n$ (بقفزة Hann مثل $N/4$) (3.3.52)

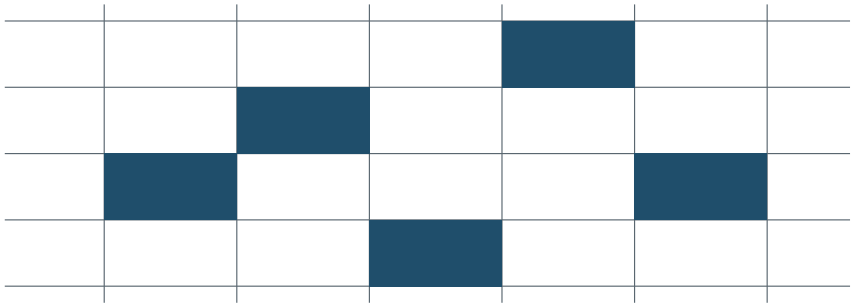
التكلفة: $O\Big(\frac{L}{H} \cdot N \log N\Big)$ (4.3.52)

جدول الرموز

الرمز	المعنى	ملاحظة
m	فهرس الإطار الزمني	المحور الأفقي
H	القفزة (hop)	$H = N/2$ أو $N/4$ شائع
F_{jk}	مرشّحات mel المثلثية	40–80 مرشّحاً نموذجياً
OLA	إعادة التركيب بالجمع المتداخل	شرط النافذة
L	طول الإشارة الكلّي	يحدّد عدد الإطارات

شبكة زمن-تردد بدقّة ثابتة: STFT

STFT: fixed-resolution time–frequency grid



كلّ خليّة حجمها ثابت (نافذة واحدة) ⇒ ترددات عالية بدقّة زمنية جيدة ودقّة ترددية ،

.STFT: X[m,k]=\sum_n x[n]w[n-m]e^{-2\pi i kn/N}

شكل ٢٠٥٢: *
STFT: شبكة زمن-تردد بدقة ثابتة تنتج المخطوط الطيفي

برهان (مخطط).

١. **(1.3.52)** نافذة منزلقة ثم DFT في كلّ موضع: تعريفٌ مباشر.

٢. **(3.3.52)** (STFT inverse) للاستعادة الدقيقة نحتاج أن «تجمع» النوافذ المتداخلة إلى الواحد ⇐ شرط COLA.

٣. **(2.3.52)** mel مقياسٌ لوغاريتمي يقارب إدراك الأذن؛ واللوغاريتم يضغط المدى الديناميّ.

٤. **(4.3.52)** عدد الإطارات L/H مضروباً في تكلفة FFT لكلّ إطار. ■

شروط الصحّة: اختيار H يوازن التكلفة والسلاسة؛ وشرط (3.3.52) يخصّ النافذة والقفزة معاً (Hann مع $H = N/2$ تحقّقه).

أمثلة محلولة (15)

مثال (3.52-1): إعداد STFT نموذجي

المعطيات: $f_s = 16$ kHz، نافذة 25 ms، قفزة 10 ms. الحل: الخطوة 1: $N = 400$ ⇐ نقرّب إلى 512، و$H = 160$. الخطوة 2: عدد الإطارات لثانية = 100. النتيجة: 100 إطار/ث و257 خليّة تردّد. الربط بالذكاء الاصطناعي: هذه أعداد واجهات التعرّف على الكلام القياسية.

مثال (3.52-2): تأثير القفزة على التحصيل

المعطيات: $H = N$ مقابل $H = N/4$. الحل: الخطوة 1: $H = N$ ⇐ إطارات منفصلة (تقتير خشن)؛ $H = N/4$ ⇐ سلاسة زمنية. النتيجة: التداخل يعوّض توهين الحواف. الربط بالذكاء الاصطناعي: التداخل نظيرُ stride=1 في الشبكات.

مثال (3.52-3): قراءة spectrogram

المعطيات: خطوط أفقية ثابتة مقابل خطوط مائلة. الحل: الخطوة 1: الأفقية = نغمات ثابتة، المائلة = تردّد متغيّر (chirp/glissando). النتيجة: القراءة البصرية تعادل تحليلاً. الربط بالذكاء الاصطناعي: CNNs على spectrogram تتعلّم هذه الأشكال تلقائيّاً.

مثال (3.52-4): log-mel والضغط

المعطيات: 257 خليّة ⇐ 80 مرشّحاً mel. الحل: الخطوة 1: نضغط التردّد بمرشّحات مثلثية متزايدة العرض ⇐ 80 قيمة. الخطوة 2: لوغاريتم ⇐ مدى ديناميّ مناسب. النتيجة: تمثيلٌ مضغوط ومدركيّاً مناسب. الربط بالذكاء الاصطناعي: مدخلات wav2vec/Whisper من هذا النوع.

مثال (3.52-5): MFCC

المعطيات: نريد ميزاتٍ غير مترابطة. الحل: الخطوة 1: DCT على log-mel $\Rightarrow$ معاملات قليلة (13) غير مترابطة تقريباً. النتيجة: ضغطٌ إضافي وتبييض تقريبي. الربط بالذكاء الاصطناعي: تبييضُ الميزات يحسّن تدريب النماذج الخطّية.

مثال (3.52-6): إعادة البناء من الطيف

المعطيات: نريد تعديل الصوت ثم إعادته. الحل: الخطوة 1: نعدّل $|X|$ ونحتفظ بالطور الأصلي $\Rightarrow$ STFT inverse بـOLA. الخطوة 2: تقدير الطور إن فقدناه (Grffiin–Lim) $\Rightarrow$ تدهور ملحوظ. النتيجة: الطور جوهرّي للإعادة. الربط بالذكاء الاصطناعي: المُرمِّزات العصبية تتعلّم الطور (الفصل 53).

مثال (3.52-7): التكلفة الحسابية

المعطيات: دقيقة صوت، $N = 512$، $H = 160$. الحل: الخطوة 1: إطارات $= \frac{60 \cdot 16000}{160} = 6000$ $\Rightarrow$ $6000 \cdot 512 \cdot 9 \approx 2.8 \times 10^7$ عملية. النتيجة: سريع بما يكفي للزمن الحقيقي. الربط بالذكاء الاصطناعي: مبرّرُ استخدام spectrogram في الأنظمة الآنية.

مثال (3.52-8): النافذة والتسرّب في STFT

المعطيات: نافذة مستطيلة قصيرة. الحل: الخطوة 1: تسرّبٌ كبير $\Rightarrow$ «ظلال» حول الخطوط الأفقية. الخطوة 2: Hann تحسّن العرض على حساب الدقة. النتيجة: المفاضلة نفسها (6.51). الربط بالذكاء الاصطناعي: اختيار النافذة يؤثّر في جودة الميزات المتعلَّمة.

مثال (3.52-9): spectrogram بوصفه صورة

المعطيات: هل يجوز إدخاله إلى CNN؟ الحل: الخطوة 1: نعم — وأشهر النتائج في تصنيف الصوت جاءت هكذا. الخطوة 2: لكنّه يفقد الطور ويقيّد بالمفاضلة الزمنية-الترددية. النتيجة: نجاحٌ عملي مع قيود نظرية. الربط بالذكاء الاصطناعي: واجهات «مباشرة من الموجة» (wav2vec) تتجاوز هذه القيود.

مثال (3.52-10): دقة الزمن في كشف الكلمات

المعطيات: نريد تحديد بداية كلمة بدقة 10 ms. الحل: الخطوة 1: نحتاج $H \leq 160$ عيّنة $\Rightarrow$ تكلفة أعلى. النتيجة: دقة الكشف تُشترى بالحساب. الربط بالذكاء الاصطناعي: مفاضلة التأخير مقابل الدقة في الأنظمة الصوتية.

مثال (3.52-11): تحليل chirp

المعطيات: إشارة يتردّدها من 100 إلى 8000 Hz خلال ثانية. الحل: الخطوة 1: في spectrogram نراها خطّاً

مائلاً واضحاً. النتيجة: أداةٌ مثالية للحظات التردّد المتغيّر. الربط بالذكاء الاصطناعي: الرادار والسونار يعتمدان هذا التحليل.

مثال (12-3.52): قمع الضجيج بالطرح الطيفي

المعطيات: ضجيجٌ ثابت تُقدَّر طاقة طيفه في فترات الصمت. الحل: الخطوة 1: نطرح $|N|^2$ من $|X|^2 \Rightarrow$ «spectral subtraction». النتيجة: تحسينٌ سمعي بسيط. الربط بالذكاء الاصطناعي: تقنيةٌ كلاسيكية سبقت التعلّم العميق بعقود.

مثال (13-3.52): حدود spectrogram في التوليد

المعطيات: نريد توليد صوت من spectrogram فقط. الحل: الخطوة 1: الطور مفقود $\Rightarrow$ نحتاج تقديره $\Rightarrow$ جودة أقل. النتيجة: مبرّرُ النماذج الموجية المباشرة. الربط بالذكاء الاصطناعي: WaveNet/HiFi-GAN تحلّ هذه المشكلة (6.53).

مثال (14-3.52): التكيّف مع معدّل العيّنات

المعطيات: إشارة 48 kHz بدل 16. الحل: الخطوة 1: نكسر النافذة إلى 1024/1536 للحفاظ على نفس المدد الزمنية. النتيجة: نفس المفاضلة بمقاييس مختلفة. الربط بالذكاء الاصطناعي: توحيدُ الميزات عبر معدّلات عيّنات مختلفة.

مثال (15-3.52): من spectrogram إلى المويجات

المعطيات: إشارة فيها أحداث قصيرة ونغمات طويلة معاً. الحل: الخطوة 1: spectrogram بنافذة واحدة لا يخدم الاثنين $\Rightarrow$ مويجات بمقاييس متعدّدة. النتيجة: الدافع العملي للمويجات. الربط بالذكاء الاصطناعي: الجسر إلى 4.52.

أخطاء شائعة

١. **الخلط بين حجم النافذة والقفزة:** الأول للدقة والثاني للتحصيل.

٢. **تجاهل شرط OLA عند إعادة البناء:** تشويهات في المخرج.

٣. **نسيان أن spectrogram يفقد الطور:** يمنع إعادة بناء مثالية.

٤. **استخدام عدد قنوات mel بلا مبرّر:** قرارٌ مدركي ومهماتي.

٥. **الظنّ أن الدقة تزيد بالقفزة الأصغر:** تزيد التحصيل لا الدقة.

تمهيد استفهامي

تخيّل عدسةً بدل النافذة: عند التردّدات العالية تستعمل **عدسة مكبّرة صغيرة** (نافذة ضيّقة: أين الحدث بالضبط؟)، وعند التردّدات المنخفضة **عدسة واسعة** (نافذة طويلة: ما التردّد بالضبط؟). هذا بالضبط ما تفعله المويجة: نسخةٌ واحدة من «موجة صغيرة» تُمدّ وتُضغط وتُنقل، فتغطّي مستطيلاتٍ مختلفة الأشكال في مربع الزمن-التردّد — بدل شبكة STFT الثابتة.

ولماذا هذا أفضل؟ لأنّ أغلب إشارات العالم ليست «نغمة طويلة» ولا «نقرة قصيرة» فقط، بل **مزيجٌ بمقاييس مختلفة**: صورةٌ فيها مساحات ناعمة وحوافّ حادّة، أو إشارة قلب فيها نبضات سريعة على إيقاع بطيء. المويجات تعطي كلّ مقياسٍ النافذة التي تناسبه، فتضغط التمثيل وتتركّز الطاقة في معاملات قليلة — وهذا سرّ تفوّقها في JPEG2000.

صياغة رسمية

$$\psi_{a,b}(t) = \frac{1}{\sqrt{a}}\,\psi\!\left(\frac{t-b}{a}\right), \qquad a>0,\ b\in\mathbb{R} \tag{1.4.52}$$

$$\text{(CWT)}\quad W_x(a,b) = \int x(t)\,\overline{\psi_{a,b}(t)}\,dt = \langle x, \psi_{a,b}\rangle \tag{2.4.52}$$

$$\text{شرط القبول (admissibility):}\quad C_\psi = \int_0^\infty \frac{|\Psi(\omega)|^2}{\omega} d\omega < \infty \iff \int \psi = 0 \tag{3.4.52}$$

$$\text{إعادة البناء:}\quad x(t) = \frac{1}{C_\psi}\iint W_x(a,b)\,\psi_{a,b}(t)\,\frac{da\,db}{a^2} \tag{4.4.52}$$

$$f \approx \frac{f_c}{a}\quad \text{(المقياس تردّداً:}\quad (f_c \text{ التردّد المركزي للمويجة}) \tag{5.4.52}$$

جدول الرموز

الرمز	المعنى	ملاحظة
ψ	المويجة الأُمّ	$\int\psi = 0$
a	مقياس (scale)	كبير ⇒ تردّد منخفض
b	إزاحة (translation)	الموضع الزمني
C_ψ	ثابت القبول	يسمح بإعادة البناء
Ψ	تحويل فوريه للمويجة	شرطه التناظر حول الصفر تقريباً
f_c	التردّد المركزي	للتحويل بين a وf

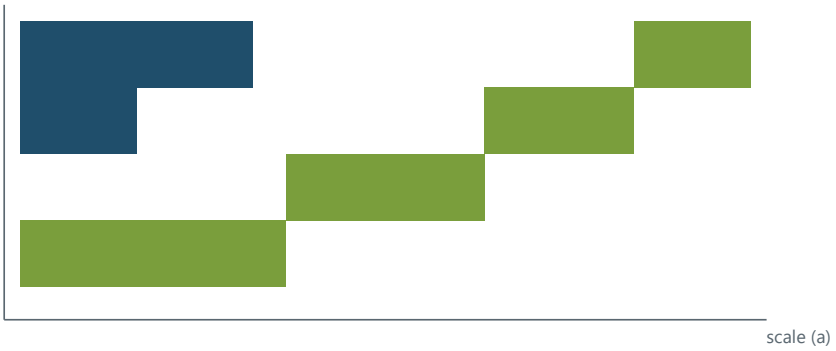
برهان (مخطط)

١. **(2.4.52)** المويجات $\psi_{a,b}$ عائلةٌ من دوالّ متحجّمة ومنزاحة، والتحويل جداءٌ داخلي ⇒ معاملات.

٢. **(3.4.52)** من $\int\psi=0$ يزول التردّد الصفري فتتلاشى $|\Psi(\omega)|^2/\omega$ عند الصفر ⇒ التكامل منتهٍ.

٣. **(4.4.52)** نُثبت بمبرهنة الجداء الداخلي المزدوج: $C_\psi\langle x,y\rangle = \iint\langle x,\psi_{a,b}\rangle\langle\psi_{a,b},y\rangle\frac{dadb}{a^2}$ (من تغيير المتغيّرات في مجال فوريه).

المويجات: مقياس متعدّد بدلاً من نافذة ثابتة
Wavelets: multi-resolution tiling



مربّعات المويجات: ضيقة عند التردّد العالي (دقّة زمنية) وواسعة عند المنخفض (د
psi_{a,b}(t)=\frac{1}{\sqrt a}\psi\!\left(\frac{t-b}{a}\right)\ :تحجيمٌ وإزاحة للمو

شكل ٥٢.٣: *
المويجات: تبليط متعدد المقاييس لمربع الزمن-التردد

٤. **(5.4.52)** تحجيمُ المويجة بـa يوسّع طيفها بعامل $1/a \Rightarrow$ التردّد يتناسب عكسيّاً. ■

شروط الصحّة: CWT تمثيلٌ **فائض** (redundant): معاملات أكثر من اللازم — وهو مفيد للتحليل ومكلف للتخزين، ولذا نلجأ إلى DWT المنفصل (5.52) للضغط.

أمثلة محلولة (15)

مثال (5.4.52-1): مويجة هار

المعطيات: $\psi(t) = 1$ على $[0, 1/2)$ و-1 على $[1/2, 1)$. الحل: الخطوة 1: $\int \psi = 0$ ✓ ومتعمّدة مع إزاحاتها.
النتيجة: أبسطُ مويجة، حسّاسة للقفزات. الربط بالذكاء الاصطناعي: أداةٌ كلاسيكية لكشف الحواف وتقطيع البيانات.

مثال (5.4.52-2): مويجة مكسيكية القبعة (Ricker)

المعطيات: $\psi(t) = (1 - t^2)e^{-t^2/2}$ (مشتقة غاوسية الثانية). الحل: الخطوة 1: $\int \psi = 0$ ✓، وناعمة $\Rightarrow$ حسّاسة للقمم لا القفزات. النتيجة: مناسبة لاكتشاف النبضات. الربط بالذكاء الاصطناعي: تستخدم في تحليل الإشارات الحيوية والزلازل.

مثال (5.4.52-3): مويجة Morlet

المعطيات: $\psi(t) = e^{-t^2/2}e^{i\omega_0 t}$ معدّلة (بطرح الطرف الصفري). الحل: الخطوة 1: طيفها غاوسي حول ω_0 $\Rightarrow$ مويجة «شبه نغمة». النتيجة: جيدة لتحليل الترددات الموضعية. الربط بالذكاء الاصطناعي: شائعة في تحليل

EEG/MEG.

مثال (4-4.52): قراءة scalogram

المعطيات: رسم $|W(a,b)|^2$ بالمعكوس: المحور العمودي المقياس. الحل: الخطوة 1: القيم الكبيرة عند مقاييس صغيرة $\Rightarrow$ أحداث سريعة؛ وعند كبيرة $\Rightarrow$ مكوّنات بطيئة. النتيجة: قراءةٌ بصرية متعدّدة المقاييس. الربط بالذكاء الاصطناعي: scalogram يُستخدم مدخلاتٍ للشبكات في الصوت.

مثال (5-4.52): كشف قفزة بمويجة

المعطيات: إشارة ناعمة فيها قفزة واحدة. الحل: الخطوة 1: معاملات المقياس الصغير تكبر عند القفزة فقط. النتيجة: تحديدٌ دقيق لموضع القفزة ومقياسها. الربط بالذكاء الاصطناعي: كشفُ الشذوذ في السلاسل الزمنية بالمويجات.

مثال (6-4.52): إخفاء مكوّن بطيء

المعطيات: اتجاهٌ عام (trend) يغطّي الحدث المهم. الحل: الخطوة 1: نأخذ معاملات المقاييس الصغيرة فقط $\Rightarrow$ نزيل الاتجاه. النتيجة: فصلُ المقاييس تنظيفٌ للبيانات. الربط بالذكاء الاصطناعي: إزالةُ الاتجاه خطوة preprocessing قياسية.

مثال (7-4.52): العلاقة بين المقياس والتردّد

المعطيات: مويجة بـ$f_c = 0.8$ Hz عند $a = 10$. الحل: الخطوة 1: $f \approx 0.8/10 = 0.08$ Hz $\Rightarrow$ مكوّن بطيء جدّاً. النتيجة: المقياس الكبير = التردّد المنخفض. الربط بالذكاء الاصطناعي: المقاييس الهرميّة في الشبكات تقابل هذه الفكرة.

مثال (8-4.52): شرط القبول والتردّد الصفري

المعطيات: مويجة بمتوسط غير صفري. الحل: الخطوة 1: $|\Psi(0)| \neq 0$ $\Rightarrow$ التكامل في (3.4.52) يتباعد $\Rightarrow$ لا إعادة بناء. النتيجة: المتوسط الصفري شرطٌ لا كمال. الربط بالذكاء الاصطناعي: نظيرُه أنّ مرشّحات CNN «بلا انحياز» تكشف التغيّرات لا المتوسط (1.52).

مثال (9-4.52): CWT لضغط أم لا؟

المعطيات: تمثيلٌ فائض بمعاملات $a \times b$ كثيرة. الحل: الخطوة 1: للتحليل نعم؛ وللتخزين لا (نحو أضعاف حجم الإشارة). النتيجة: CWT للتحليل، وDWT للضغط. الربط بالذكاء الاصطناعي: التمثيلات الفائضة مفيدة للميزات لا للتخزين.

مثال (10-4.52): الجمع بين مقاييس (multi-scale)

المعطيات: صورة طبيعية. الحل: الخطوة 1: المقاييس الكبيرة تحمل المساحات، والصغيرة تحمل الحوافّ. النتيجة: تمثيلٌ هرمي مطابق لإدراك الرؤية. الربط بالذكاء الاصطناعي: الهرميّة في الشبكات (U-Net) من هذا المنطق.

مثال (11-4.52): المويجة بوصفها مرشّح نطاق

المعطيات: تحليل CWT عند مقياس a. الحل: الخطوة 1: يعادل تمرير الإشارة عبر مرشّح نطاق حول f_c/a. النتيجة: CWT = بنك مرشّحات متصل. الربط بالذكاء الاصطناعي: هذا ما تتعلّمه طبقات CNN في مراحلها الأولى.

مثال (12-4.52): متانة للإزاحة

المعطيات: إزاحة الإشارة بمقدار صغير. الحل: الخطوة 1: معاملات CWT تُزاح بالمقدار نفسه (تغيّر طور لا مقدار في المويجات المركّبة). النتيجة: تمثيلٌ قابل للاستخدام في التصنيف. الربط بالذكاء الاصطناعي: الثبات للترجمة مطلوب في مميّزات الصوت (والتشتّت يحقّقه في 8.52).

مثال (13-4.52): مويجات ثنائية البعد

المعطيات: صورة. الحل: الخطوة 1: مويجات باتجاهات (أفقية، عمودية، قطرية) ⇒ حسّاسة للحواف باتجاهاتها. النتيجة: تمثيلٌ اتجاهي (curvelets/contourlets لاحقاً). الربط بالذكاء الاصطناعي: المرشّحات الاتجاهية في CNN المتقدّمة.

مثال (14-4.52): تطبيق في تشخيص الآلات

المعطيات: اهتزاز محمّل دوري بعيب موضعي. الحل: الخطوة 1: العيب يظهر نبضاتٍ قصيرة ⇒ معاملات مقياس صغير دورية. النتيجة: كشفُ العيب قبل تفاقمه. الربط بالذكاء الاصطناعي: الصيانة التنبؤية تعتمد هذا التحليل.

مثال (15-4.52): المويجات مقابل STFT للضغط

المعطيات: إشارة بحوافّ ونغمات. الحل: الخطوة 1: STFT بدقة واحدة يهدر؛ والمويجات تكيّف الدقة ⇒ معاملات أقلّ لنفس الجودة. النتيجة: مبرّرُ JPEG2000. الربط بالذكاء الاصطناعي: المويجات في ضغط الصور الطبية (حيث الحوافّ حرجة).

أخطاء شائعة

١. **استخدام مويجة بمتوسط غير صفري:** لا إعادة بناء.

٢. **الخلط بين المقياس والتردّد:** علاقة عكسية (5.4.52).

٣. **توقّع أن CWT يضغط:** هو تمثيل فائض للتحليل.

٤. **نسيان أن المويجة المناسبة تعتمد على شكل الحدث:** هار للقفزات، Morlet للتردّدات.

٥. **استخدام مويجات بمقاييس عشوائية في الضغط:** DWT يختار مقاييس ثنائية منظّمة.

تمهيد استفهامي

CWT يعطي تمثيلاً غنيّاً لكنّه فائض: معاملات أكثر من عيّنات الإشارة. فإن أردنا ضغطاً، فنحتاج تمثيلاً **بعدد معاملات مساوٍ لعدد العيّنات** — لا أكثر. كيف؟

الحل العبقري: نأخذ مقاييس **ثنائية** فقط ($a = 2^j$) وإزاحات **ثنائية** ($b = k2^j$) $\Rightarrow$ قاعدةٌ متعامدة بعدد معاملات = عدد العيّنات، وتنفيذٌ ببنك مرشّحات بتكلفة $O(N)$ — أرخص من FFT نفسها! هذه هي DWT، وإطارها النظري هو **التحليل متعدد الدقة** (MRA): سلسلةٌ من الفضاءات المتداخلة $V_j \subset V_{j+1}$، كلّ مستوى يضيف التفاصيل التي عجز عنها الذي قبله.

وبفضل تعامدها، يصير الضغط حساباً مباشراً: احذف التفاصيل الصغيرة، وخطؤك معلوم ببارسيفال.

صياغة رسمية

$$\phi(t) = \sqrt{2}\sum_{n} h_n\,\phi(2t-n), \qquad \psi(t) = \sqrt{2}\sum_{n} g_n\,\phi(2t-n) \tag{1.5.52}$$

بنك التحليل: $$cA_j[k] = \sum_{n} h_{n-2k}\,cA_{j-1}[n], \qquad cD_j[k] = \sum_{n} g_{n-2k}\,cA_{j-1}[n] \tag{2.5.52}$$

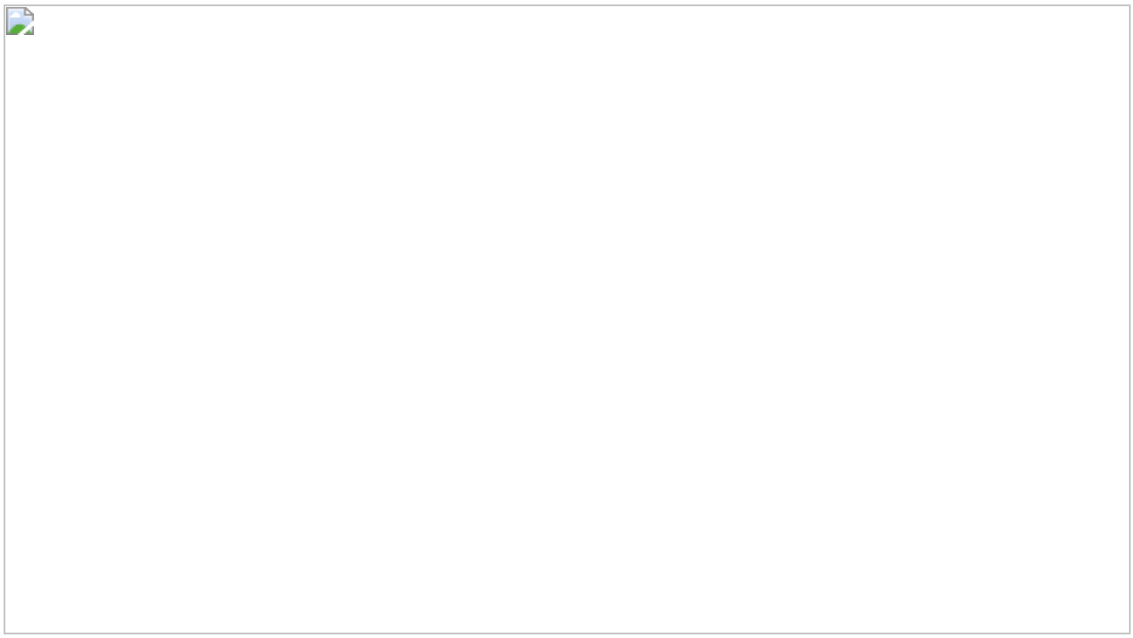
الشرط الثنائي (quadrature): $$g_n = (-1)^n h_{L-1-n}, \qquad \sum_n h_n h_{n-2k} = \delta_k, \qquad \sum_n h_n = \sqrt{2} \tag{3.5.52}$$

MRA: $$V_{j+1} = V_j \oplus W_j, \qquad L^2 = \overline{V_0 \oplus \bigoplus_{j\ge 0} W_j} \tag{4.5.52}$$

التعقيد: $$\underbrace{N + \tfrac{N}{2} + \tfrac{N}{4} + \cdots}_{<2N} = O(N) \tag{5.5.52}$$

جدول الرموز

الرمز	المعنى	ملاحظة
ϕ, ψ	دالة القياس والمويجة	wavelet / scaling
h, g	مرشّحا التمرير المنخفض والعالي	زوج متعامد
$cA,\ cD$	التقريبات والتفاصيل	detail / approximation
V_j, W_j	فضاءات القياس والتفاصيل	هرميّة MRA
$\downarrow 2$	تقليل العيّنات	يحفظ عدد المعاملات
L	طول المرشّح	يحدّد انتقال النطاق



شكل ٤.٥٢: *
DWT: بنك مرشحات التحليل وإعادة التركيب مع تقليل العينات

برهان (مخطط)

١. **(1.5.52)** معادلتا القياس (two-scale relations) تعرّفان ϕ وψ من المرشّحين.

٢. **(2.5.52)** الإسقاط على V_j وW_j يعطي الالتفاف ثم التقليل بـ2.

٣. **(3.5.52)** شرطا التعامد والكمال مكتوبان على المرشّح؛ ويضمنان إعادة بناء تامّة.

٤. **(5.5.52)** كلّ مستوى يعمل على نصف طول السابق $\Rightarrow$ مجموعٌ هندسي $< 2N$. ■

شروط الصحّة: المعاملات عند الحدود تحتاج معالجة (تمديد/دوران/انعكاس) وإلا ظهرت آثار حوافّ. والمرشّحات الطويلة (Daubechies) أنعم لكنها أوسع انتقالاً.

أمثلة محلولة (15)

مثال (1-5.52): مرشّحا هار

المعطيات: $h = (1/\sqrt{2}, 1/\sqrt{2})$ و$g = (1/\sqrt{2}, -1/\sqrt{2})$. الحل: الخطوة 1: تحقّق (3.5.52): $\sum h_n = \sqrt{2}$ ✓، والتعامد ✓. النتيجة: أبسط بنك مرشّحات متعامد. الربط بالذكاء الاصطناعي: هار = متوسطات وفروق — كما في تجميع CNN واختزالها.

مثال (2-5.52): DWT لخطوة واحدة

المعطيات: $x = [2, 4, 6, 8]$. الحل: الخطوة 1: $cA = [3, 7]$ (متوسطات) و$cD = [-1, -1]$ (فروق). النتيجة: 4 معاملات مقابل 4 عيّنات ✓. الربط بالذكاء الاصطناعي: نفسُ عدد المعاملات بلا تكرار.

مثال (52.5-3): مستويات متعدّدة

المعطيات: إشارة طولها 1024، ثلاثة مستويات. الحل: الخطوة 1: cA_3 بطول 128 وcD_3, cD_2, cD_1 بأطوال 128،256،512 ⇒ المجموع 1024 ✓. النتيجة: تمثيلٌ هرمي كامل. الربط بالذكاء الاصطناعي: الهرميّة في الشبكات (تقليل الأبعاد تدريجيّاً).

مثال (52.5-4): طاقة التفاصيل

المعطيات: إشارة ناعمة + ضجيج. الحل: الخطوة 1: الضجيج يظهر في cD بمقاييس صغيرة ⇒ معظم الطاقة هناك. النتيجة: فصلُ الضجيج عن البنية. الربط بالذكاء الاصطناعي: تنظيفُ البيانات قبل التعلّم.

مثال (52.5-5): ضغط باقتطاع cD

المعطيات: نحذف 90٪ من معاملات التفاصيل الصغيرة. الحل: الخطوة 1: الخطأ = مجموع مربّعات المحذوف (بارسيفال) ⇒ نحسبه قبل الحذف. النتيجة: ضغطٌ بميزانية خطأ معلنة. الربط بالذكاء الاصطناعي: JPEG2000 يفعل ذلك بالضبط.

مثال (52.5-6): مقارنة تكلفة DWT وFFT

المعطيات: $N = 10^6$. الحل: الخطوة 1: DWT بمرشّح طول 8: $16 \times 10^6 \approx$ عملية. الخطوة 2: FFT: $10^8 \approx$ ⇒ DWT أرخص بنحو 6 أضعاف. النتيجة: مبرّرُ استخدام المويجات في الأنظمة السريعة. الربط بالذكاء الاصطناعي: الالتفافات السريعة والمويجات في الأجهزة الطرفية.

مثال (52.5-7): الانتقال المثالي والمويجات الحقيقية

المعطيات: مرشّح طوله 4 (Daubechies-2). الحل: الخطوة 1: انتقال النطاق ليس حادّاً ⇒ تسريب بين المقاييس المجاورة. النتيجة: مفاضلة الطول مقابل الانتقال. الربط بالذكاء الاصطناعي: نظيرُ حجم النواة مقابل حدّة المرشّح في CNN.

مثال (52.5-8): معالجة الحدود

المعطيات: إشارة قصيرة بـDWT بمستويات كثيرة. الحل: الخطوة 1: تمديدٌ صفري يخلق «قفزة» عند الحافة ⇒ معاملات كبيرة وهمية. الخطوة 2: التمديد الانعكاسي (symmetric) أفضل. النتيجة: الحدود تحتاج عناية. الربط بالذكاء الاصطناعي: padding في CNN نفس المشكلة (zero vs reflect).

مثال (52.5-9): ثبات الإزاحة في DWT

المعطيات: إزاحة الإشارة بعيّنة واحدة. الحل: الخطوة 1: بسبب 2 ↓ تتغيّر المعاملات جذريّاً ⇒ DWT

غير ثابتة للإزاحة. النتيجة: عيبٌ بنيوي (و«stationary» WT يعالجه). الربط بالذكاء الاصطناعي: مبرّرُ «shfit-invariant» variants في الشبكات.

مثال (5.52-10): إعادة البناء والتحقق

المعطيات: معاملات من (5.52-2). الحل: الخطوة 1: رفع العيّنات 2 ↑ ثم الترشيح والجمع ⇒ نستعيد x تماماً بالمرشّحات المتعامدة. النتيجة: إعادة بناء تامّة (perfect reconstruction). الربط بالذكاء الاصطناعي: autoencoders بالمويجات تضمن إعادة بناء دقيقة.

مثال (5.52-11): DWT في بعدين (صورة)

المعطيات: صورة 512×512. الحل: الخطوة 1: تطبيقٌ على الصفوف ثم الأعمدة ⇒ أربع نطاقات (LL, LH, HL, HH) لكلّ مستوى. النتيجة: تمثيلٌ هرمي اتجاهي. الربط بالذكاء الاصطناعي: wavelet-pooling والشبكات الهرمية.

مثال (5.52-12): اختيار المويجة

المعطيات: إشارة ناعمة قطعيّاً. الحل: الخطوة 1: مويجة قصيرة (هار) تعطي معاملات كثيرة عند القفزات، وDaubechies الأطول أنعم لكن أقل موضعية. النتيجة: الاختيار بحسب المهمة. الربط بالذكاء الاصطناعي: اختيارُ النواة في CNN قرارٌ مماثل.

مثال (5.52-13): DWT والمويجات المتعلَّمة

المعطيات: نريد مويجات تناسب بياناتنا. الحل: الخطوة 1: نجعل المرشّحات معاملاتٍ قابلة للتعلّم ⇒ «wavelet network». النتيجة: تمثيلٌ متكيّف. الربط بالذكاء الاصطناعي: المرشّحات المتعلَّمة في الطبقة الأولى خيرٌ من الثابتة غالباً.

مثال (5.52-14): تفاصيل متفرقة (sparsity)

المعطيات: صورة طبيعية بـDWT. الحل: الخطوة 1: أغلب معاملات HH صغيرة جدّاً ⇒ تمثيل متناثر ⇒ ضغط فعّال. النتيجة: التناثر مقياسُ جودة التمثيل. الربط بالذكاء الاصطناعي: التناثر في التمثيلات العصبية هدفُ التنظيم.

مثال (5.52-15): DWT في الشبكات الحديثة

المعطيات: نموذجٌ يتعامل مع سلاسل طويلة جدّاً. الحل: الخطوة 1: المويجات تعطي ضغطاً بمعاملات قليلة ⇒ تخفيف الحمل قبل الانتباه/الالتفاف. النتيجة: تسريعٌ بتمثيل متعدد المقاييس. الربط بالذكاء الاصطناعي: transforms Multiwavelet في معالجة السياق الطويل (الفصل 53).

أخطاء شائعة

١. **تجاهل معالجة الحدود:** معاملات وهمية عند الأطراف.

٢. **توقّع ثبات للإزاحة في DWT:** غير متاح (إلا بنسخ معدّلة).

٣. **الخلط بين المرشّحين** h, g: الأول منخفض والثاني عالٍ.

٤. **مستويات أكثر من اللازم:** cA يصير قصيراً جدّاً $\Rightarrow$ لا معنى.

٥. **نسيان شرط** $\sum h_n = \sqrt{2}$: ي التطبيع فيعيد بناءً بمقياس خاطئ.

تمهيد استفهامي

صورةٌ مليئة بالضجيج، وتريد تنظيفها بلا أن تفقد الحوافّ. تنعيمٌ غاوسي يزيل الضجيج **والحواف معاً.** فما الحل؟

الحل المويجي يعتمد على ملاحظةٍ بسيطة وعميقة: **الإشارة تتركّز، والضجيج ينتشر.** فمعاملات الإشارة قليلة وكبيرة، ومعاملات الضجيج كثيرة وصغيرة وموزّعة على كلّ المقاييس. إذن: ضع عتبةً، فما دونها صفر، وما فوقها يُحتفظ به (منقوصاً أو لا). هذه هي «العتبة» (thresholding)، وجمالها أنّ خطأها محسوب ببارسيفال، وأنّها تحفظ الحوافّ لأنّ معاملات الحوافّ كبيرة.

وهذه الفكرة نفسها هي قلبُ L1 والتناثر في التعلّم الآلي (الفصلان 22 و31): عقابٌ يدفع الصغار إلى الصفر ويترك الكبار.

صياغة رسمية

$$\text{عتبة صلبة (hard)}: \hat{c} = \begin{cases} c, & |c| > \lambda \\ 0, & |c| \le \lambda \end{cases} \qquad \text{عتبة ناعمة (soft)}: \hat{c} = \operatorname{sgn}(c)\max(|c| - \lambda, 0) \tag{1.6.52}$$

$$\text{العتبة العالمية (Donoho–Johnstone)}: \lambda = \sigma\sqrt{2\ln N}, \qquad \hat{\sigma} = \frac{\operatorname{MAD}(cD_1)}{0.6745} \tag{2.6.52}$$

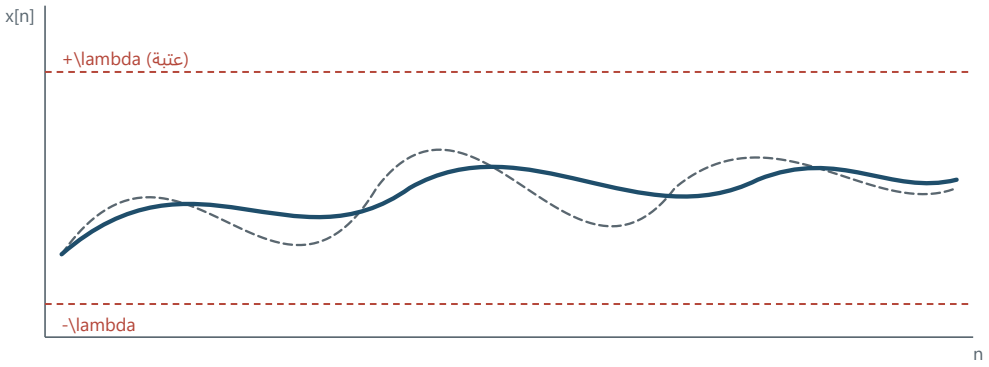
$$\text{مخاطرة Stein غير المتحيّزة (SURE)}: \lambda^\star = \arg\min_{\lambda} \ \mathrm{SURE}(\lambda) \tag{3.6.52}$$

$$\text{الخطأ المتوقّع (oracle)}: \mathbb{E}\|\hat{f} - f\|^2 \approx \sum_{k} \min(c_k^2, \sigma^2) \tag{4.6.52}$$

جدول الرموز

الرمز	المعنى	ملاحظة
λ	العتبة	تصغر مع N الكبير نسبياً
σ	انحراف الضجيج	يُقدَّر من أفضل مقياس
MAD	وسيط الانحراف المطلق	مقدّر متين للضجيج
SURE	تقدير مخاطرة Stein	يختار العتبة بلا معرفة f
oracle	حدٌّ أعلى مثالي	للمقارنة النظرية

إزالة الضجيج بعتبة المعاملات المويجية
Wavelet thresholding denoising



العتبة الناعمة: \hat c=\mathrm{sgn}(c)\max(|c|-\lambda,0)\ — تقليصٌ بلا انقطاع؛ الضجيج ينتشر على كلّ المعاملات صغيراً، والإشارة تتركّز في قليلٍ كبير منها.

شكل ٥٠٥٢: *
إزالة الضجيج بعتبة المعاملات المويجية

برهان (مخطط)

١. **(2.6.52)** بما أنّ الضجيج الأبيض الغاوسي معاملاته غاوسية، فإنّ أقصى قيمة لـ N متغيّرٍ غاوسي مستقل يبرز بـ $\sigma\sqrt{2\ln N}$ ⇒ أيّ معامل فوقها «إشارة» على الأرجح.

٢. **(3.6.52)** SURE يعطي مقدّراً غير متحيّز لمخاطرة L^2 بلا معرفة الإشارة الأصلية ⇒ نختار λ بالتحسين.

٣. **(4.6.52)** بمقارنة «الاحتفاظ» مقابل «الحذف» لكلّ معامل: الخسارة الدنيا $\min(c^2,\sigma^2)$.

٤. **(العتبة الناعمة)** هي الحلّ الأمثل لمسألة $\min \frac{1}{2}(\hat c-c)^2+\lambda|\hat c|$ ⇒ صلة مباشرة بـLasso. ■

شروط الصحّة: تفترض ضجيجاً أبيض غاوسي مستقلاً، وللضجيج الملوّن نعاير كلّ مقياس بتباينه. والعتبة الناعمة تُدخل انحيازاً في المعاملات الكبيرة (تقلّص بمقدار λ).

أمثلة محلولة (15)

مثال (6.52-1): تقدير ضجيج من أفضل مقياس

المعطيات: cD_1 بمعاملات صغيرة كثيرة. الحل: الخطوة 1: $\hat\sigma = \mathrm{MAD}/0.6745$ ⇒ مقدّر متين لا يتأثّر بالإشارة. النتيجة: تقديرٌ عملي بلا معرفة مسبقة. الربط بالذكاء الاصطناعي: المقدّرات المتينة (robust) بديلُ المتوسط عند وجود شذوذ.

مثال (6.52-2): حساب العتبة العالمية

المعطيات: $N = 4096$ و$\hat{\sigma} = 1$. الحل: الخطوة 1: $\lambda = \sqrt{2 \ln 4096} \approx 4.08$. النتيجة: أيّ معامل $|c| > 4.08$ يُعتبر إشارة. الربط بالذكاء الاصطناعي: نظيرُه اختيارُ قوة التنظيم بمقياس $1/\sqrt{n}$.

مثال (6.52-3): عتبة ناعمة بالأرقام

المعطيات: $c = 5$ و$\lambda = 4.08$. الحل: الخطوة 1: $\hat{c} = 5 - 4.08 = 0.92$ (ناعمة) مقابل 5 (صلبة). النتيجة: الناعمة تقلّص الكبار قليلاً لكنها أكثر سلاسة. الربط بالذكاء الاصطناعي: الفرق بين L1 (تقلّص) و«Hard threshold».

مثال (6.52-4): تنظيف صورة

المعطيات: صورة بضجيج $\sigma = 20$ من 255. الحل: الخطوة 1: DWT بمستويين، عتبة ناعمة، إعادة بناء $\Rightarrow$ تحسّن PSNR بنحو 4–6 dB. النتيجة: تنظيفٌ فعّال يحفظ الحوافّ. الربط بالذكاء الاصطناعي: التنظيف الكلاسيكي سبق الشبكات وظلّ مرجعاً.

مثال (6.52-5): أثر العتبة على الحوافّ

المعطيات: صورة فيها حوافّ قوية. الحل: الخطوة 1: معاملات الحوافّ كبيرة $\Rightarrow$ تبقى؛ والضجيج صغير $\Rightarrow$ يزول. النتيجة: حفظُ الحواف ميزة المويجات على التنعيم. الربط بالذكاء الاصطناعي: المرشّحات الحافظة للحواف (bilateral) تهدف الأمر نفسه.

مثال (6.52-6): SURE مقابل العتبة العالمية

المعطيات: إشارة متناثرة جدّاً. الحل: الخطوة 1: SURE يختار عتبةً أدنى $\Rightarrow$ يحتفظ بمعاملات أكثر $\Rightarrow$ خطأ أقل. النتيجة: تكيّفُ العتبة مفيد. الربط بالذكاء الاصطناعي: ضبطُ المعاملات الفائقة بالتحقق المتقاطع نظيره.

مثال (6.52-7): التناثر مقياس جودة

المعطيات: تمثيلان للإشارة نفسها. الحل: الخطوة 1: أيّهما يعطي معاملات كبيرة أقلّ $\Rightarrow$ أفضل للضغط والتنظيف. النتيجة: التناثر معيار اختيار التمثيل. الربط بالذكاء الاصطناعي: التناثر في التمثيلات العصبية يقاس ويُنظَّم.

مثال (6.52-8): العلاقة بـLasso

المعطيات: مسألة $\min \frac{1}{2}\|y - X\beta\|^2 + \lambda\|\beta\|_1$. الحل: الخطوة 1: في القاعدة المتعامدة: الحلّ عتبة ناعمة بالضبط. النتيجة: «العتبة = Lasso في قاعدة متعامدة». الربط بالذكاء الاصطناعي: ربطٌ مباشر بالفصل 22 (التنظيم المحدّب).

مثال (6.52-9): عتبة مقياسيّة

المعطيات: ضجيج ملوّن (غير أبيض). الحل: الخطوة 1: نعاير كلّ مستوى بتباين الضجيج فيه ⇒ عتبة لكلّ مقياس. النتيجة: تنظيفٌ أفضل للضجيج الملوّن. الربط بالذكاء الاصطناعي: التطبيعُ الطبقي (LayerNorm) يفعل شيئاً مشابهاً للتمثيلات.

مثال (6.52-10): حدود التنظيف

المعطيات: ضجيجٌ بقوة قريبة من الإشارة. الحل: الخطوة 1: لا عتبة تنقذ: المعاملات لا تتميّز ⇒ فقدانٌ أو بقايا ضجيج. النتيجة: حدودٌ معلوماتية لا خوارزمية. الربط بالذكاء الاصطناعي: حدودُ نسبة الإشارة إلى الضجيج تحكم كلّ متعلّم.

مثال (6.52-11): تقييم النتيجة

المعطيات: صورة منظَّفة، والمطلوب: قياس الجودة. الحل: الخطوة 1: PSNR/SSIM مقابل الأصل؛ وإن لم تتوفّر: مقياس بلا مرجع (NIQE). النتيجة: القياس جزءٌ من الحلّ. الربط بالذكاء الاصطناعي: مقاييس التقييم تحدّد ما «يتعلّمه» النموذج.

مثال (6.52-12): التنظيف والهبوط المتدرّج

المعطيات: تكرار العتبة وإعادة البناء. الحل: الخطوة 1: كلّ تكرار = إسقاط متناوب (نكوارزميات proximal). النتيجة: إطارٌ موحّد مع خوارزميات التحسين. الربط بالذكاء الاصطناعي: صلةٌ بالفصل 22 (ISTA/FISTA).

مثال (6.52-13): التنظيف في الزمن الحقيقي

المعطيات: ميكروفون بضجيج خلفية. الحل: الخطوة 1: DWT قصير الإطار بعتبة متكيّفة ⇒ تأخير منخفض. النتيجة: مناسب للمكالمات. الربط بالذكاء الاصطناعي: الأنظمة الآنية تفضّل الطرائق $O(N)$.

مثال (6.52-14): الشبكات تتعلّم العتبة

المعطيات: نموذج تنظيف عميق. الحل: الخطوة 1: شبكة CNN على معاملات مويجية تتعلّم عتبة متكيّفة لكلّ معامل. النتيجة: أفضل من العتبة الثابتة. الربط بالذكاء الاصطناعي: «learned shrinkage» تطبيقٌ مباشر لهذه النظرية.

مثال (52.6-15): التنظيف قبل التعلّم

المعطيات: بيانات تدريب ملوّثة. الحل: الخطوة 1: تنظيفٌ مويجي يحسّن نسبة الإشارة للضجيج ⇒ تعميم أفضل. النتيجة: preprocessing يُترجَم تحسناً في التعميم. الربط بالذكاء الاصطناعي: جودةُ البيانات مقدَّمة على حجم النموذج.

أخطاء شائعة

١. **استخدام عتبة واحدة لكلّ المقاييس مع ضجيج ملوّن:** يعالَج بالمعايرة.

٢. **توقّع إزالة كاملة للضجيج:** مفاضلة بين البقايا وفقدان التفاصيل.

٣. **الخلط بين العتبتين الصلبة والناعمة:** الأولى متقطّعة والثانية متصلة.

٤. **تقدير σ من معاملات تحمل إشارة:** يضخّم التقدير ⇒ استخدم أفضل مقياس.

٥. **نسيان أن التنظيف يدخل انحيازاً:** العتبة الناعمة تقلّص الكبار.

تمهيد استفهامي

هل يمكن تمثيل زمني-ترددي **بدقة أعلى** من حدود spectrogram؟ نعم — على الورق. توزيع فيغنر–فيل (WVD) يعطي تركيزاً طيفياً ممتازاً: نغمةٌ نقيّة تظهر خطّاً رفيعاً، ونبضة تظهر خطّاً عمودياً حادّاً، بلا التوسيع الذي تفرضه النافذة.

لكن الثمن قاسٍ ومفاجئ: إن كانت الإشارة تحوي **مكوّنين**، ظهر بينهما «حدٌّ متقاطع» (cross-term) — بنيةٌ وهمية في منتصف المسافة بينهما، قد تكون أقوى من المكوّنين أنفسهما! فتوزيع فيغنر–فيل يشبه عدسةً ممتازة تضيف صوراً أشباحاً. والعلاج المعروف (تنعيمٌ في الزمن-التردد، عائلة كوهين) يعيدنا جزئيّاً إلى مفاضلة الريبة: **لا دقة قصوى بلا ثمن.**

صياغة رسمية

$$W_x(t,\omega) = \int x\left(t+\tfrac{\tau}{2}\right)\overline{x\left(t-\tfrac{\tau}{2}\right)}\,e^{-i\omega\tau}\,d\tau \tag{1.7.52}$$

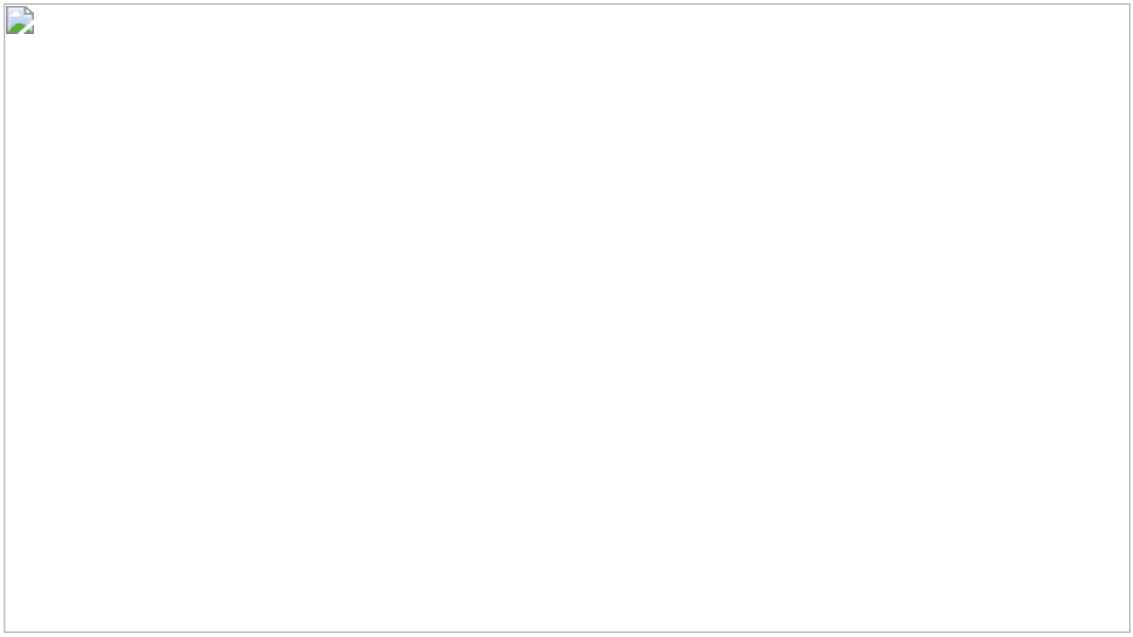
خصائص مرغوبة: $\int W\,d\omega = |x(t)|^2, \quad \frac{1}{2\pi}\int W\,dt = |X(\omega)|^2, \quad \iint W = E_x$ (2.7.52)

الحدود المتقاطعة: $x = x_1 + x_2 \Rightarrow W_x = W_{x_1} + W_{x_2} + 2\Re\{W_{x_1 x_2}\}$ (3.7.52)

العلاج (عائلة كوهين): $C_x(t,\omega) = \iint \phi(\theta,\tau)e^{-i(\theta t+\tau\omega)}A_x(\theta,\tau)\,d\theta d\tau$ (4.7.52)

جدول الرموز

الرمز	المعنى	ملاحظة
W_x	توزيع فيغنر–فيل	يمكن أن يكون سالباً!
$W_{x_1x_2}$	الحدّ المتقاطع	يظهر بين كلّ زوج مكوّنين
A_x	دالة الغموض (ambiguity)	مجال «التأخير-الدوبلر»
ϕ	نواة التنعيم	تحدّد العائلة (Choi–Williams…)
$\Re$	الجزء الحقيقي	الحدود المتقاطعة حقيقية التذبذب



شكل ٦.٥٢: *
توزيع فيغنر-فيل وظهور الحدود المتقاطعة بين مكونين

برهان (مخطط)

١. **(1.7.52)** تعريفٌ مباشر بالارتباط الذاتي اللحظي (وهو تحويل فوريه لـ$R_x(t,\tau)$ في τ).

٢. **(2.7.52)** بالتكامل على المتغيّر الآخر ⇒ الهوامش الزمانية والترددية صحيحة (ميزة كبرى).

٣. **(3.7.52)** بتوسيع الجداء المزدوج ⇒ يظهر حدٌّ مزدوج بين x_1 وx_2 — وهو **لا يصف شيئاً موجوداً**.

٤. **(4.7.52)** التنعيم في مجال (θ,τ) يخفض الحدود المتقاطعة على حساب الدقة والهوامش. ■

شروط الصحّة: WVD ليس «طيفاً» بالمعنى الإيجابي: قد يتّخذ قيماً سالبة ⇒ لا تفسير احتمالي. واستخدامه الأمثل للمكوّن المنفرد أو بعد تنعيم مدروس.

أمثلة محلولة (15)

مثال (52.7-1): نغمة واحدة

المعطيات: $x(t) = e^{i\omega_0 t}$. الحل: الخطوة 1: $W = 2\pi\delta(\omega - \omega_0) \Rightarrow$ تركيز مثالي. النتيجة: أفضل من spectrogram بلا مقارنة. الربط بالذكاء الاصطناعي: التركيز الطيفي يسهّل فصل المكوّنات.

مثال (52.7-2): مكوّنان $\Rightarrow$ حدّ متقاطع

المعطيات: نغمتان بترددين مختلفين. الحل: الخطوة 1: يظهر حدٌّ ثالث في منتصف التردّد $\Rightarrow$ وهم. النتيجة: تفسيرٌ خاطئ إن لم ننتبه. الربط بالذكاء الاصطناعي: artfiacts تُفسد تحليل السلاسل المالية المتعددة المكوّنات.

مثال (52.7-3): الهوامش الصحيحة

المعطيات: نريد $|x(t)|^2$ من W. الحل: الخطوة 1: بالتكامل على $\omega \Rightarrow$ نحصل $|x(t)|^2$ بالضبط ✓. النتيجة: ميزة نادرة. الربط بالذكاء الاصطناعي: التمثيلات المتسقة مع الهوامش أسهل تفسيراً.

مثال (52.7-4): WVD قد يكون سالباً

المعطيات: إشارة بمكوّنين متقاربين. الحل: الخطوة 1: قيم سالبة في منطقة التذبذب $\Rightarrow$ لا تفسير «طاقة». النتيجة: الحذر في التفسير. الربط بالذكاء الاصطناعي: التوزيعات السالبة تظهر أيضاً في توزيعات فيغنر الكمّية.

مثال (52.7-5): تنعيم Choi–Williams

المعطيات: نواة تنعيم أُسّية. الحل: الخطوة 1: تخفض الحدود المتقاطعة بقوة مع بقاء تركيز مقبول. النتيجة: حلٌّ وسط عملي. الربط بالذكاء الاصطناعي: التنعيم أداةٌ عامة لمكافحة artfiacts.

مثال (52.7-6): مقارنة spectrogram وWVD

المعطيات: chirp سريع. الحل: الخطوة 1: spectrogram يوسّع الخط، وWVD يحدّده بدقة. النتيجة: الدقة مقابل الحدود المتقاطعة. الربط بالذكاء الاصطناعي: لا تمثيل متفوّق في كلّ شيء.

مثال (52.7-7): كشف مكوّن ضعيف قرب قوي

المعطيات: نغمة ضعيفة بجوار قوية. الحل: الخطوة 1: الحد المتقاطع قد يغطّي الضعيفة $\Rightarrow$ كشف خاطئ. النتيجة: WVD خطرٌ في الإشارات متعددة المكوّنات. الربط بالذكاء الاصطناعي: المكوّنات الضعيفة تُطمس في التحليلات غير المدروسة.

مثال (52.7-8): دالة الغموض

المعطيات: الرادار يريد قياس المدى والسرعة. الحل: الخطوة 1: $A_x(\theta,\tau)$ هو مجال «التأخير-الدوبلر» $\Rightarrow$ أداة الرادار الكلاسيكية. النتيجة: نظريةٌ واحدة تخدم تطبيقات متباعدة. الربط بالذكاء الاصطناعي: تمثيلات «الغموض» تُستخدم في الاسترجاع الصوتي.

مثال (52.7-9): عائلة كوهين بوصفها تعميماً

المعطيات: اختيار $\phi = 1$. الحل: الخطوة 1: نحصل WVD؛ واختيارات أخرى تعطي spectrogram وتوزيعات أخرى. النتيجة: إطارٌ موحّد. الربط بالذكاء الاصطناعي: الأُطر الموحّدة تسمح بمقارنة عادلة بين الطرائق.

مثال (52.7-10): حدود متقاطعة في الصور

المعطيات: صورة بتركيبين اتجاهيين. الحل: الخطوة 1: WVD ثنائي البعد يولّد حدوداً بينهما $\Rightarrow$ تشويش بصري. النتيجة: الأثر عام في أيّ بُعد. الربط بالذكاء الاصطناعي: تمثيلات الطاقة المربّعة لها الأثر نفسه في الشبكات.

مثال (52.7-11): التردّد الآني من WVD

المعطيات: إشارة بتردّد متغيّر. الحل: الخطوة 1: مركز ثقل WVD عند كلّ لحظة يعطي التردّد الآني بدقة. النتيجة: أداةٌ قوية للمكوّن المنفرد. الربط بالذكاء الاصطناعي: تقدير «التردّد اللحظي» في السلاسل الاقتصادية.

مثال (52.7-12: تطبيق في الصوت)

المعطيات: تحليل نبرة صوت. الحل: الخطوة 1: WVD يفصل التوافقيّات بدقة؛ لكن ظهور حدود بينها يربك. النتيجة: يُستخدم مع تنعيم أو على مكوّنات مفردة. الربط بالذكاء الاصطناعي: مميّزات الصوت الحديثة تتجنّب التمثيلات المربّعة لهذا السبب.

مثال (52.7-13): التعقيد الحسابي

المعطيات: إشارة بطول N. الحل: الخطوة 1: حساب WVD $O(N^2)$ $\Rightarrow$ أثقل من spectrogram $O(N\log N)$. النتيجة: تكلفة إضافية للدقة. الربط بالذكاء الاصطناعي: الدقة تُشترى بالحساب (قاعدة متكرّرة).

مثال (52.7-14): متى تختار WVD؟

المعطيات: مهمة بمكوّن واحد متغيّر التردّد. الحل: الخطوة 1: نعم؛ وإن تعدّدت المكوّنات فالتنعيم أو spectrogram. النتيجة: اختيارٌ مشروط ببنية الإشارة. الربط بالذكاء الاصطناعي: تشخيصُ بنية البيانات قبل اختيار التمثيل.

مثال (52.7-15): الدر المستفاد

المعطيات: كلّ تمثيل زمني-ترددي. الحل: الخطوة 1: الدقة القصوى تُشترى إمّا بحدود متقاطعة وإمّا بتنعيم وإمّا بحساب أكبر. النتيجة: لا تمثيل مجّاني. الربط بالذكاء الاصطناعي: «لا غداء مجّاني» في التمثيل كما في التعلّم.

أخطاء شائعة

١. **تفسير القيم السالبة طاقة:** WVD ليس طيف قدرة موجباً.

٢. **تجاهل الحدود المتقاطعة في الإشارات متعددة المكوّنات:** تُفسد التحليل.

٣. **الظنّ أن WVD يعفي من مبدأ الريبة:** التنعيم يعيد القيد.

٤. **استخدامه بلا تنعيم في التطبيقات العملية:** artfiacts أقوى من الإشارة أحياناً.

٥. **نسيان التكلفة** $O(N^2)$: محدد عملي مهم.

تمهيد استفهامي

في التعرّف على الأصوات، إزاحةٌ بمقدار 10 ملي ثانية يجب ألّا تغيّر التمثيل. لكنّ معاملات المويجات **تتغيّر** عند الإزاحة (52.5-9). فكيف نبني تمثيلاً **ثابتاً للترجمة** ومع ذلك غنيّاً بالمعلومات؟

الجواب يأتي من فكرةٍ بسيطة: بعد كلّ تحويل مويجي نأخذ **المقدار** (التقويم/nonlinearity)، ثم نكرّر. المقدار يلغي الطور المتغيّر بالإزاحة، والتكرار يسترجع المعلومات التي فقدناها بأخذه. الناتج: تمثيلٌ «عميق» لكن بلا أيّ معاملات متعلَّمة — شبكةٌ بُنيت بالرياضيات البحتة، تعمل ممتازاً حين تكون البيانات قليلة، وتقدّم معلومات قبلية قوية بدل التعلّم من الصفر.

هذا هو **تحويل التشتّت** (scattering transform) لستيفان مالّات — أقربُ جسر بين هذا الفصل والشبكات الالتفافية (الفصل 37): هرميّة، وتجميع، ولاخطّية، وثبات متزايد بالعمق.

صياغة رسمية

$$S_0 x = x * \phi, \qquad S_1 x = \{|x * \psi_{\lambda_1}| * \phi\}, \qquad S_2 x = \{\,||x * \psi_{\lambda_1}| * \psi_{\lambda_2}| * \phi\} \tag{1.8.52}$$

الثبات للترجمة: $\|S(x_c) - S(x)\| \to 0$ كلما زاد العمق ($|c|$ مقيساً بالمقياس) (2.8.52)

عدم التوسّع (nonexpansive): $\|Sx - Sy\| \le \|x - y\|$ (3.8.52)

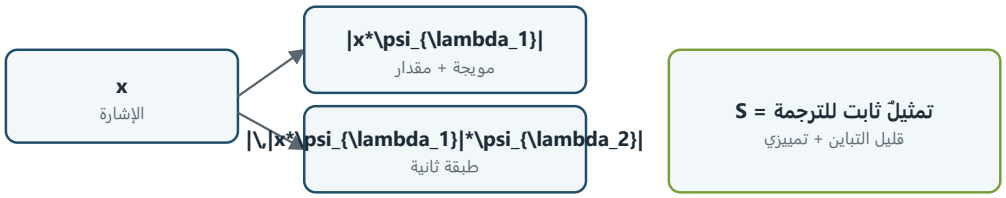
التعقيد: $O(N \log N)$ لكلّ مسار، وعدد المسارات $O(\log N)$ (4.8.52)

جدول الرموز

الرمز	المعنى	ملاحظة
ϕ	مرشّح تمرير منخفض (تجميع)	يعطي الثبات
ψ_λ	مويجة بمقياس/اتجاه λ	تستخرج التفاصيل
$\|\cdot\|$	أخذ المقدار (لاخطّية)	يلغي الطور
S_j	معاملات التشتّت بالعمق j	هرميّة
c	مقدار الإزاحة	الثبات نسبيّ للمقياس

تحويل التشتّت: تمثيلٌ ثابت للترجمة بلا تعلّم

Scattering transform: stable, untrained features



العمق يحدّد بعدد المقاييس؛ ولا توجد معاملات تُتعلّم — شبكة مبنية على الرياضيات مفيد حيث البيانات قليلة: معلومات قبلية بدل التعلّم من الصفر.

شكل ٧.٥٢: *
تحويل التشتت: تمثيل هرمي ثابت للترجمة بلا معاملات متعلمة

برهان (مخطط)

١. **(1.8.52)** تعريفٌ تكراري: كلّ طبقة = التفاف بمويجة، ثم مقدار، ثم تجميع بـϕ.

٢. **(2.8.52)** المقدار بعد الالتفاف يعادل «إلغاء الطور»؛ والتجميع يقلّل الحساسية للإزاحات الصغيرة؛ والعمق يزيد الثبات تدريجيّاً.

٣. **(3.8.52)** كلّ خطوة (التفاف بمتعامد + مقدار + تجميع) لا تزيد المسافة $\Rightarrow$ التركيب كذلك (استقرار عددي مضمون).

٤. **(4.8.52)** كلّ التفاف بـFFT؛ وعدد المسارات المفيدة لوغاريتمي (المعاملات العالية تضمحل). ■

شروط الصحّة: الثبات «موضعي»: للإزاحات الصغيرة مقابل مقياس التجميع؛ والإزاحات الكبيرة تغيّر التمثيل (وهذا مرغوب: نريد تمييزاً). والتشتّت ليس بديلاً عن التعلّم حين تتوفّر بيانات كثيرة.

أمثلة محلولة (15)

مثال (8.52-1): لماذا المقدار؟

المعطيات: إزاحة الإشارة. الحل: الخطوة 1: الالتفاف يغيّر الطور، والمقدار يلغيه ⇒ ثبات. النتيجة: المقدار هو «الممحاة» التي تزيل الطور. الربط بالذكاء الاصطناعي: التجميع (ReLU/pooling) في CNN يلعب الدور نفسه.

مثال (8.52-2: لماذا نكرّر؟)

المعطيات: بعد أخذ المقدار فقدنا معلومات الطور. الحل: الخطوة 1: التكرار يستخرج «تردّد المغلف» ⇒ يعوّض جزءاً كبيراً من المعلومات. النتيجة: عمقٌ يعوّض الفقد. الربط بالذكاء الاصطناعي: تعميق الشبكات يعوّض فقد التجميع.

مثال (8.52-3): تشتّت بلا تعلّم

المعطيات: 100 عيّنة تدريب فقط. الحل: الخطوة 1: التشتّت يعطي مميّزات جاهزة ⇒ مصنّف خطّي يكفي. النتيجة: ميزةٌ كبرى في قلّة البيانات. الربط بالذكاء الاصطناعي: الاستقراء القوي بديلُ البيانات الكثيرة.

مثال (8.52-4): مقارنة بميزات CNN المتعلَّمة

المعطيات: بيانات كثيرة جدّاً. الحل: الخطوة 1: CNN المتعلَّمة تتجاوز التشتّت عادةً (تتكيّف مع المهمة). النتيجة: لكلّ مقامه. الربط بالذكاء الاصطناعي: قاعدة: قلّة البيانات ⇒ تمثيل ثابت، كثرتها ⇒ تمثيل متعلَّم.

مثال (8.52-5): التشتّت في الصوت

المعطيات: تصنيف أصوات بيئية. الحل: الخطوة 1: تشتّت بمقياس زمني حتى ثانية ⇒ نتائج قريبة من الشبكات العميقة ببيانات أقل. النتيجة: نجاحٌ موثّق. الربط بالذكاء الاصطناعي: «Deep Scattering Spectrum» في الصوت.

مثال (8.52-6): عدم التوسّع والاستقرار

المعطيات: إشارة + ضجيج صغير. الحل: الخطوة 1: بـ(3.8.52) التمثيل لا يضخّم الضجيج ⇒ متانة. النتيجة: ضمانٌ رياضي للمتانة. الربط بالذكاء الاصطناعي: استقرار ليبِشتس للشبكات هدفُ بحث معاصر (الفصل 34).

مثال (8.52-7): عدد المسارات

المعطيات: إشارة بطول $N = 1024$ و$J = 8$ مقاييس. الحل: الخطوة 1: مسارات العمق 1: ثمانية، والعمق 2:

≈ عشرات، والأعمق تضمحل. النتيجة: تمثيلٌ مدمج نسبيّاً. الربط بالذكاء الاصطناعي: اضمحلال المعاملات يسوّغ الاقتطاع (8.50).

مثال (8-8.52): التشتّت والضجيج

المعطيات: ضجيج بمقياس دقيق. الحل: الخطوة 1: التجميع بالمستوى الأول يزيله ⇒ التمثيل يركّز على البنية. النتيجة: تنظيفٌ مدمج في التمثيل. الربط بالذكاء الاصطناعي: التجميع في CNN يلعب دور إزالة الضجيج الموضعي.

مثال (9-8.52): التشتّت بوصفه شبكة

المعطيات: قارن بالCNN. الحل: الخطوة 1: التفاف ⇒ لاخطّية ⇒ تجميع، مكرّرة؛ لكن المرشّحات مويجات ثابتة. النتيجة: CNN بمعاملات «مجمّدة» ومبرّرة نظريّاً. الربط بالذكاء الاصطناعي: يفسّر نجاح CNN من منظور التحليل الطيفي.

مثال (10-8.52): حدود الثبات

المعطيات: إزاحة كبيرة (أكبر من مقياس التجميع). الحل: الخطوة 1: التمثيل يتغيّر (وهذا مطلوب للتمييز). النتيجة: الثبات نسبي بالمقياس. الربط بالذكاء الاصطناعي: الثبات الكامل يقتل التمييز — توازن مطلوب.

مثال (11-8.52): التشتّت في الصور

المعطيات: تصنيف نسيج (texture). الحل: الخطوة 1: تشتّت بمويجات واتجاهات ⇒ مميّزات ثابتة للترجمة والدوران الموضعي. النتيجة: نتائج قوية للأنسجة. الربط بالذكاء الاصطناعي: الأنسجة تُصنَّف بالإحصاءات الطيفية لا بالأشكال.

مثال (12-8.52): مويجات متعلَّمة داخل التشتّت

المعطيات: نريد تكييف المرشّحات مع بياناتنا. الحل: الخطوة 1: «learned scattering» تجعل المرشّحات قابلة للتعلّم مع بقاء الهيكل. النتيجة: أفضل الأمرين. الربط بالذكاء الاصطناعي: اتجاهٌ بحثي نشط (هيكل رياضي + تعلّم محدود).

مثال (13-8.52): التكلفة مقابل الدقة

المعطيات: تشتّت بعمق 2. الحل: الخطوة 1: عشراتُ التفافات بـFFT ⇒ أثقل من spectrogram وأرخص من تدريب شبكة. النتيجة: مفاضلة واضحة. الربط بالذكاء الاصطناعي: التكلفة تشمل التدريب لا الاستدلال فقط.

مثال (14-8.52): التشابه مع النماذج التوليدية الحديثة

المعطيات: هرميّة التمثيل في نماذج الانتشار. الحل: الخطوة 1: كلاهما يبني تمثيلاً متعدد المقاييس ⇒ التشتّت يفسّر جزءاً من نجاحها. النتيجة: وحدةٌ مفاهيمية عبر الفصول (41 و52). الربط بالذكاء الاصطناعي: المقاييس المتعدّدة مبدأٌ عالمي في النماذج الحديثة.

مثال (15-8.52): متى لا يكفي التشتّت؟

المعطيات: مهمة تتطلّب تمثيلاً دلالياً عالي المستوى. الحل: الخطوة 1: التشتّت يمثّل البنية الطيفية لا المعنى ⇒ نحتاج تعلّماً عميقاً فوقه. النتيجة: التشتّت طبقةٌ أولى ممتازة لا نهائية. الربط بالذكاء الاصطناعي: المميّزات اليدوية/الرياضية تُغذّي النماذج المتعلَّمة.

أخطاء شائعة

١. **توقّع ثبات كامل للترجمة:** الثبات بالمقياس فقط.

٢. **اعتبار التشتّت بديلاً عن التعلّم دائماً:** يتفوّق في قلّة البيانات.

٣. **نسيان أن المقدار يفقد معلومات:** التكرار يعوّض جزئيّاً.

٤. **زيادة العمق بلا حساب:** المعاملات تضمحل سريعاً.

٥. **الخلط بين التشتّت والمويجات البسيطة:** الأول هرمي متعدد الطبقات.

تمارين (30)

مستوى أول:

١. احسب $\Delta_t \Delta_\omega$ للنبضة الغاوسية وتحقّق المساواة في الحدّ.

٢. احسب STFT لإشارة $[1,1,1,1,2,2,2,2]$ بنافذة 4 وقفزة 4.

٣. اقرأ :spectrogram ماذا يعني خط أفقي؟ ومائل؟

٤. تحقّق من $\int \psi = 0$ لمويجة هار.

٥. احسب DWT بمستوى واحد لـ$x = [2,4,6,8]$ بمرشّح هار.

٦. تحقّق من شرط $\sum h_n = \sqrt{2}$ لمرشّح هار.

٧. احسب العتبة العالمية لـ$N = 1024$ و$\hat{\sigma} = 2$.

٨. طبّق عتبة ناعمة على $c = -3$ بعتبة 2.

٩. بيّن أن WVD لنغمة واحدة يعطي دالة ديراك في التردّد.

١٠. اكتب معاملات التشتّت بالعمق 1 لإشارة معلومة.

مستوى ثان:

١. برهن (1.2.52) بمتفاوتة كوشي–شفارتس (مخطط كامل).

٢. بيّن أن زيادة طول النافذة تحسّن التردّد وتُضعف الزمن كمّياً.

٣. برهن أن المقياس a يقابل التردّد f_c/a.

٤. اشترط على المرشّحين h, g إعادة بناء تامّة واكتبها صراحةً.

٥. برهن أن العتبة الناعمة هي حلّ مسألة L1 في قاعدة متعامدة.

٦. احسب تكلفة DWT لثلاثة مستويات مقابل FFT للطول نفسه.

٧. بيّن كيف يظهر الحدّ المتقاطع في مجموع نغمتين (حساب رمزي).

٨. برهن (3.8.52) عدم التوسّع عبر خطوات التحويل.

٩. قارن ثبات spectrogram وDWT والتشتّت للإزاحة ترتيبياً.

١٠. صغ مسألة اختيار النافذة بوصفها تحسيناً بمقياسين متضادّين.

مستوى ثالث:

١. صمّم خطوة تنظيف لإشارة ECG بضجيج 50 Hz وضجيج عشوائي (اذكر الخطوات).

٢. صورة طبية: هل تختار JPEG أم JPEG2000؟ علّل طيفياً.

٣. شبكة CNN لا تتعلّم التفاصيل: اقترح تمثيلاً مويجياً مدخلاتٍ وحلّلاً الأثر.

٤. بيانات قليلة جدّاً: قارن التشتّت بتعلّم نقل (transfer) من حيث المبرّر.

٥. كيف تكتشف أنّ تمثيلك يعاني من حدود متقاطعة؟

٦. اربط بين التناثر المويجي والتنظيم L1 في الشبكات.

٧. صغ «الهرميّة» في U-Net بوصفها تحليلاً متعدد الدقة.

٨. اشرح لماذا قد تتفوّق مويجات متعلَّمة على ثابتة، ومتى لا.

٩. قدّر عدد المعاملات المطلوبة لتمثيل صورة بمويجات بدقة 99٪ مقابل فوريه.

١٠. اربط بين العتبة المويجية والتوقّف المبكر في تدريب الشبكات.

ملخص الفصل

النظرية	الصيغة المحوريّة	الدرس العملي
مبدأ الريبة	$\Delta_t \Delta_\omega \geq 1/2$	لا دقة مزدوجة كاملة — اختر موضعك
STFT	نافذة منزلقة + DFT	log-mel وspectrogram
CWT	بمقياس وإزاحة $\psi_{a,b}$	تحليل متعدد المقاييس (فائض)
DWT	بنك مرشّحات $O(N)$	ضغط متعامد بعدد المعاملات نفسه
العتبة	$\lambda = \sigma\sqrt{2\ln N}$	تنظيف يحفظ الحواف (= Lasso)
فيغنر–فيل	طاقة مربّعة عالية الدقة	حدود متقاطعة إن تعدّدت المكوّنات
التشتّت	التفاف ⇒ مقدار ⇒ تجميع	تمثيل ثابت بلا تعلّم

الجسر إلى الفصل 53: كلّ ما سبق كان أدواتٍ «مصمّمة»: مرشّحات ومويجات يختارها المهندس. أمّا اليوم فالمرشّحات **تُتعلَّم**: CNN تتعلّم بنك مرشّحات، والمحوّلات تتعلّن مزجاً، ونماذج الحالة تتعلّم أقطابها. الفصل القادم يضع هذه النماذج في اللغة الطيفية نفسها.

جدول الرموز (فهرس الفصل)

الرمز	المعنى
$w,\ H$	نافذة التحليل وقفزتها
$X[m,k],\ S[m,k]$	STFT والمخطوط الطيفي
$\psi,\ \phi$	المويجة الأُمّ ودالة القياس
$a,\ b$	المقياس والإزاحة
$h,\ g$	مرشّحا التمرير المنخفض والعالي
$cA,\ cD$	التقريبات والتفاصيل
$\lambda,\ \sigma$	العتبة وانحراف الضجيج
$W_x,\ A_x$	توزيع فيغنر–فيل ودالة الغموض
S_j	معاملات التشتّت بالعمق j

نهاية الفصل الثاني والخمسين — ومنه نعبر إلى معالجة الإشارة الحديثة والتعلّم العميق على الإشارات في الفصل الثالث والخمسين.

معالجة الإشارة الحديثة والتعلّم العميق على الإشارات

الشعار: «المرشّح الذي كان يُصمَّم باليد صار يُتعلَّم — لكنّ قوانين الطيف لم تتغيّر: من خالفها تعلّم الوهم.»

تمهيد قصصي للفصل: من مرشّح المهندس إلى مرشّح الشبكة

في التسعينيات، كان تصميم مرشّحٍ رقمي علماً قائماً بذاته: تحدّد نطاق التمرير، ونطاق الإيقاف، والتموّج المسموح، ثم تختار عائلة، (Butterworth، Chebyshev (Elliptic وتحسب المعاملات من جداولٍ أو برامج. كلّ مرشّحٍ قصةُ مفاضلة بين حدّة الانتقال وتموّج النطاق وطول المرشّح.

ثم جاء التعلّم العميق فقلب الطاولة: **الشبكة الالتفافية تتعلّم مرشّحاتها.** لا أحد يحدّد لها نطاق التمرير؛ هي تستنتجه من البيانات. لكنّ المفارقة الجميلة أنّ المرشّحات التي تتعلّمها الطبقة الأولى من CNN على الصور تشبه — بشكلٍ مدهش — مرشّحات غابور والمويجات التي صمّمناها في الفصل الماضي! كأنّ الشبكة تعيد اكتشاف قرنٍ من التحليل الطيفي من تلقاء نفسها.

هذا الفصل يضع النماذج الحديثة في لغة الإشارة: المرشّحات، والالتفاف، والانتباه، ونماذج الحالة، والمُرمِّزات. وسترى أنّ كثيراً من «أحدث» الأفكار — تهيئة S4، وتوسيع WaveNet، ومزج FNet — هي حلولٌ طيفية لمسائل قديمة.

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. تصميم مرشّح FIR/IIR والتحقق من استقراره بمواقع الأقطاب.

٢. حساب تكلفة الالتفاف في الزمن مقابل التردّد واتخاذ القرار عملياً.

٣. تفسير الالتفاف الموسّع (dilated) وحساب الحقل الاستقبالي الأُسّي.

٤. تحليل تعقيد الانتباه $O(n^2)$ ومقارنة بدائله الطيفية.

٥. صياغة نموذج الحالة SSM/S4 وربط ذاكرته بمواقع الأقطاب (HiPPO).

٦. فهم المُرمِّزات العصبية ومشكلة إعادة بناء الطور.

٧. استخدام التكبير الطيفي والتعلّم الذاتي الإشراف على الإشارات.

المتطلبات المسبقة

الفصول 51 و52، والفصل 37 (الشبكات الالتفافية)، والفصل 39 (المحوّلات)، والفصل 49 (تحويل Z).

خريطة الفصل

القسم	القانون/النظرية	عدد الأمثلة المحلولة
1.53	المرشّح الرقمي: المفردات	—
2.53	**المرشّحات الرقمية FIR/IIR وتصميمها**	15
3.53	**الالتفاف ترشيحاً متعلّماً وتكلفته**	15
4.53	**الالتفاف الموسّع والحقل الاستقبالي الأُسّي**	15
5.53	**الانتباه على الزمن وتعقيده وبدائله**	15
6.53	**نماذج الحالة المنظّمة SSM/S4**	15
7.53	**المُرمِّزات العصبية وتوليد الموجة**	15
8.53	**التكبير الطيفي والتعلّم الذاتي الإشراف**	15
9.53	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

Frequency Cutoff · Stability · Zeros & Poles · Function Transfer · IIR · FIR · Filter Digital
Attention · Field Receptive · Convolution Dilated · Filter Learnable · Band Transition ·
· Vocoder Neural · HiPPO · S4 · Model State-Space · Transformers Efficient · Complexity
Speech Sefl-Supervised · SpecAugment · Reconstruction Phase

المرشّح نظامٌ خطّي ثابت زمنياً (LTI) يحوّل الإشارة، ويُقرأ كاملاً من **دالة التحويل**:

$$H(z) = \frac{Y(z)}{X(z)} = \frac{\sum_{k=0}^{M} b_k z^{-k}}{1 + \sum_{k=1}^{N} a_k z^{-k}}, \qquad |H(e^{i\omega})| = \text{مطال الاستجابة الترددية} \tag{1.1.53}$$

الرمز	المعنى	ملاحظة
b_k	معاملات التلقيم الأمامي (أصفار)	FIR
a_k	معاملات التلقيم الراجع (أقطاب)	IIR
ω_c	تردّد القطع	حدّ النطاق
δ	تموّج النطاق	مفاضلة التصميم
L	طول المرشّح	أطول ⇒ انتقال أحدّ

القاعدة الذهبية: الأصفار تشكّل الطيف «نقصاً»، والأقطاب تصنع «قمماً»؛ والاستقرار كلّه في مواقع الأقطاب (5.6.49): داخلُ دائرة الوحدة آمن، وخارجها انفجار.

تمهيد استفهامي

تريد أن تزيل الترددات فوق 4 kHz من تسجيل. تصميمٌ واحد لا يكفي: فالمرشّح «المثالي» (قطع حادّ، تمرير مثالي) غير قابل للتحقيق — استجابته النبضية لا متناهية، وقطعُها يولّد رنيناً (ظاهرة غيبس التي عرفناها!). فنحن أمام تصميمٍ بمفاضلات معلنة: كم تموّجاً نقبل في نطاق التمرير؟ وكم ترديفاً في نطاق الإيقاف؟ وكم طولاً للمرشّح نستطيع؟

هنا ينقسم الطريق إلى مدرستين: **FIR** (لا تلقيم راجع، مستقرّ دائماً، وطورٌ خطّي ممكن) و**IIR** (تلقيم راجع، كفاءة أعلى بمرتبة، لكنّ استقراره مشروط بمواقع الأقطاب). الاختيار بينهما ليس ذوقاً بل حسابُ تكلفةٍ وشرطِ طورٍ واستقرار.

صياغة رسمية

$$\text{FIR: } y[n] = \sum_{k=0}^{L-1} h_k x[n-k], \qquad H(z) = \sum_{k} h_k z^{-k} \tag{1.2.53}$$

$$\text{IIR: } y[n] = \sum_{k=0}^{M} b_k x[n-k] - \sum_{k=1}^{N} a_k y[n-k], \qquad H(z) = \frac{B(z)}{A(z)} \tag{2.2.53}$$

$$\text{الاستقرار (BIBO): } \sum |h[n]| < \infty \iff \text{كلّ أقطاب } H \text{ داخل } |z| < 1 \tag{3.2.53}$$

$$\text{متماثل): } h_k = h_{L-1-k} \Rightarrow \arg H(\omega) = -\omega \frac{L-1}{2} \quad \text{(FIR الطور الخطّي} \tag{4.2.53}$$

$$\text{طول FIR بنافذة: } L \approx \frac{4}{\Delta f / f_s} \quad (\Delta f \text{ عرض الانتقال}) \tag{5.2.53}$$

جدول الرموز

الرمز	المعنى	ملاحظة
h_k	الاستجابة النبضية	معاملات FIR
$A(z)$	مقام دالة التحويل	جذوره = الأقطاب
BIBO	محدود الدخل ⇒ محدود الخرج	تعريف الاستقرار
طور خطّي	تأخيرٌ ثابت لكلّ التردّدات	لا تشويه شكلي
$\Delta f / f_s$	عرض الانتقال النسبي	يحكم الطول

برهان (مخطط)

١. **(1.2.53–2.2.53)** من تعريف الالتفاف والتلقيم الراجع، ثم تحويل Z.

٢. **(3.2.53)** الاستجابة النبضية لـ $H(z) = \frac{1}{1-pz^{-1}}$ هي p^n؛ ومجموعها المطلق منتهٍ ffi $|p| < 1 \Rightarrow$ الشرط لكلّ الأقطاب.

٣. **(4.2.53)** التماثل يجعل $H(e^{i\omega}) = e^{-i\omega(L-1)/2}\cdot$(دالة حقيقية) ⇒ الطور خطّي.

٤. **(5.2.53)** من علاقة نافذة كايزر التقريبية بين الترديف وعرض الانتقال والطول. ■

شروط الصحّة: IIR غير مستقر إن خرج قطب؛ والطور غير الخطّي في IIR يشوّه شكل النبضة (مهم في ECG). وFIR بطول كبير مكلف لكنّه قابل للتوازي.

أمثلة محلولة (15)



شكل ١٠٥٣: *
مقارنة بنيتي FIR وIIR من حيث التلقيم الراجع والاستقرار والأقطاب

مثال (2.53-1): متوسط متحرّك = FIR بسيط

المعطيات: $h = (1/3, 1/3, 1/3)$. الحل: الخطوة 1: $H(z) = \frac{1+z^{-1}+z^{-2}}{3}$ ⇒ أصفار عند جذور الوحدة الثلاثة. الخطوة 2: $|H|$ يصفّر عند $\omega = 2\pi/3$ ⇒ يزيل هذا التردّد تماماً. النتيجة: مرشّح تمرير منخفض بسيط. الربط بالذكاء الاصطناعي: التنعيم المتوسط في CNN مرشّح FIR بهذا المعنى.

مثال (2.53-2): استقرار IIR

المعطيات: قطب عند 1.05. الحل: الخطوة 1: $|p| > 1$ ⇒ الاستجابة النبضية تنمو ⇒ الخرج ينفجر. النتيجة: غير مستقر إطلاقاً. الربط بالذكاء الاصطناعي: نظيرُه انفجار التدرّج في RNN (4.49-7).

مثال (2.53-3): طول FIR من عرض الانتقال

المعطيات: $f_s = 16$ kHz وانتقال 400 Hz. الحل: الخطوة 1: $L \approx 4 \cdot 16000/400 = 160$ معامل. النتيجة: الانتقال الأحدّ ⇒ مرشّح أطول. الربط بالذكاء الاصطناعي: مفاضلة حجم النواة مقابل حدّة الترشيح في CNN.

مثال (2.53-4): الطور الخطّي يحفظ الشكل

المعطيات: نبضة ECG تمرّ بمرشّحين: FIR متماثل وIIR. الحل: الخطوة 1: الأول يؤخّر كلّ التردّدات بالقدر نفسه ⇒ الشكل محفوظ. الخطوة 2: الثاني يؤخّرها تفاضلياً ⇒ تشويه شكلي. النتيجة: FIR متماثل مفضّل في التشخيص الطبي. الربط بالذكاء الاصطناعي: في الشبكات: Padding «same» يحفظ المحاذاة الزمنية.

مثال (2.53-5): تصميم بنافذة Hamming

المعطيات: نريد FIR بطول 64 بتردّد قطع 25.0 من f_s. الحل: الخطوة 1: استجابة مثالية sinc h_{ideal} مقطوع $\Rightarrow$ تموّج (غيبس!). الخطوة 2: نضرب بنافذة Hamming $\Rightarrow$ نخفض التموّج ونوسّع الانتقال. النتيجة: مفاضلة معلومة (6.52). الربط بالذكاء الاصطناعي: التنعيم في التصميم يحمي من الآثار الاصطناعية.

مثال (2.53-6): Butterworth مقابل Chebyshev

المعطيات: نحتاج انتقالاً حادّاً بطول قليل. الحل: الخطوة 1: Butterworth: أعظم استواء بلا تموّج؛ Chebyshev: تموّج في نطاق مقابل انتقال أحدّ. النتيجة: الاختيار بحسب متطلبات التموّج. الربط بالذكاء الاصطناعي: نظيرُه اختيار الدالة الموجية/التنظيم بحسب المهمة.

مثال (2.53-7): مرشّح تمرير نطاق للكلام

المعطيات: نريد 300–3400 Hz للهاتف. الحل: الخطوة 1:FIR أو IIR بقطعين $\Rightarrow$ نطاق المكالمة الكلاسيكي. النتيجة: هذا سبب «صوت الهاتف» المألوف. الربط بالذكاء الاصطناعي: نطاق الميزات يحدّد ما يمكن تمثيله.

مثال (2.53-8): كفاءة IIR

المعطيات: نفس المواصفات بـFIR طول 200 مقابل IIR من الدرجة 8. الحل: الخطوة 1: FIR: 200 عملية لكلّ عيّنة؛ IIR: 17 $\Rightarrow$ توفيرٌ بنحو 12 ضعفاً. النتيجة: IIR أرخص بكثير. الربط بالذكاء الاصطناعي: RNN أرخص معاملاتيّاً من CNN الطويلة للسبب ذاته.

مثال (2.53-9): استقرار بعد التكميم

المعطيات: معاملات IIR مكمّمة بتثبيت النقطة. الحل: الخطوة 1: التكميم قد يُزيح قطباً إلى خارج الوحدة $\Rightarrow$ انفجار. النتيجة: التحقّق بعد التكميم إلزامي. الربط بالذكاء الاصطناعي: تكميمُ النماذج (INT8) قد يزعزع الاستقرار — يُفحص بعده.

مثال (2.53-10): مرشّح تفاضلي = كاشف حواف

المعطيات: $h = (1, -1)$. الحل: الخطوة 1: $|H| = 2|\sin(\omega/2)|$ $\Rightarrow$ يصفّر التردّد المنخفض ويمرّر العالي $\Rightarrow$ كاشف حواف. النتيجة: أصغر مرشّح تمرير عالٍ. الربط بالذكاء الاصطناعي: مرشّحات الحواف/Sobel في CNN من هذا النوع.

مثال (2.53-11): ترشيح في الزمن الحقيقي

المعطيات: تأخير FIR بطول 128. الحل: الخطوة 1: التأخير الجماعي 64 عيّنة (4 ms عند 16 kHz) ⇒ مقبول للمكالمات. النتيجة: التأخير يُحسب من الطول. الربط بالذكاء الاصطناعي: زمن الاستجابة في النماذج الآنية يُقاس بالعيّنات.

مثال (2.53-12): أثر الطور في الصوت

المعطيات: نفس المطال وأطوار مختلفة. الحل: الخطوة 1: الصوت يتغيّر إدراكيًّا ⇒ الطور ليس تفصيلاً. النتيجة: مرشّحات الطور الصفري تستخدم في الصوت الحسّاس. الربط بالذكاء الاصطناعي: المُرمِّزات تتعلّم الطور (7.53).

مثال (2.53-13): FIR متعلَّم في CNN

المعطيات: نواة 5×5 في الطبقة الأولى. الحل: الخطوة 1: 25 معاملاً = مرشّح FIR ثنائي البعد متعلَّم. النتيجة: CNN بنك مرشّحات FIR متعلَّم. الربط بالذكاء الاصطناعي: هذا أعمق ربط بين الفصل والشبكات الالتفافية.

مثال (2.53-14): مرشّح لا يزيل الضجيج بل يخفيه

المعطيات: ضجيج داخل نطاق الإشارة. الحل: الخطوة 1: أيّ مرشّح خطّي سيزيل جزءاً من الإشارة معه ⇒ لا حلّ تردّدي. النتيجة: حدود الترشيح الخطّي. الربط بالذكاء الاصطناعي: الفصل غير الخطّي/التعلّمي يتجاوز هذه الحدود.

مثال (2.53-15): الفحص العملي للمرشّح

المعطيات: مرشّح مصمّم، والمطلوب: التحقق. الحل: الخطوة 1: نمرّر نغمةً بمطال واحد ونقيس الخرج ⇒ نرسم $|H|$ عمليّاً. النتيجة: قياسٌ لا ثقة. الربط بالذكاء الاصطناعي: اختبارُ الوحدات في أنظمة الإشارة كما في البرمجيات.

أخطاء شائعة

١. **تجاهل فحص الأقطاب في IIR:** الانفجار كارثي لا تدريجي.

٢. **الظنّ أن FIR أفضل دائماً:** الكفاءة لصالح IIR.

٣. **نسيان أثر الطور غير الخطّي:** يشوّه الأشكال الزمنية.

٤. **استخدام مرشّح خطّي لفصل ضجيج متداخل النطاق:** مستحيل تردّديّاً.

٥. **عدم إعادة فحص الاستقرار بعد التكميم:** القطب قد يخرج.

تمهيد استفهامي

الالتفاف في الشبكة ليس «تشبيهاً» بالمرشّح — هو مرشّح FIR بالحرف، لكنّ معاملاته تُتعلَّم بالانتشار العكسي بدل أن تُحسب من جداول. الفرق الجوهري أنّنا لا نفرض عليه شكل الاستجابة الترددية: نترك البيانات تحدّدها.

لكنّ الحساب يبقى حساباً: التفافٌ مباشر $O(N \cdot L)$ مقابل $O(N \log N)$ عبر FFT. فمتى ننتقل؟ القاعدة العملية: النواة الصغيرة (3×3) مباشرةٌ دائماً، والنواة الكبيرة (> 32) تستحقّ FFT، وبينهما اختبارٌ على العتاد. وليست المفاضلة نظريةً فقط: فالالتفاف المباشر يتيح تكاملاً أفضل مع GPU والذاكرة.

صياغة رسمية

$$y[n] = \sum_{k=0}^{L-1} w_k \, x[n-k] \quad \Longleftrightarrow \quad Y(\omega) = W(\omega) X(\omega) \tag{1.3.53}$$

تكلفة مباشرة: $O(N \cdot L)$، تكلفة FFT: $O(N \log N + L \log L)$ (2.3.53)

نقطة التعادل العملية: $L^\star \approx 16\text{–}64$ بحسب العتاد والدفعات (3.3.53)

الاستجابة الترددية المتعلَّمة: $W(\omega) = \sum_k w_k e^{-i\omega k}$ (4.3.53)

جدول الرموز

الرمز	المعنى	ملاحظة
w_k	أوزان النواة المتعلَّمة	معاملات FIR
L	طول النواة	يحدّد التكلفة والانتقال
$W(\omega)$	استجابة النواة الترددية	ما «تسمعه» الطبقة
$L^\star$	طول التحول إلى FFT	قرار عتادي
N	طول الإشارة	يحدّد مكسب FFT

برهان (مخطط)

١. **(1.3.53)** مبرهنة الالتفاف (1.6.51) مطبّقة على نواة متعلَّمة.

٢. **(2.3.53)** حسابٌ مباشر لعدد العمليات.

٣. **(3.3.53)** المفاضلة الفعلية تعتمد على عرض النطاق الترددي للذاكرة وعدد الدفعات لا على O وحدها.

٤. **(4.3.53)** التحويل المنفصل للأوزان يعطي الاستجابة؛ ومراقبتها أداةُ تشخيص للتعلّم. ■

شروط الصحّة: الالتفاف «الصحيح» (cross-correlation) في المكتبات ليس التفافاً رياضياً (بلا قلب النواة) — والفرق لا يهمّ مع التعلّم. والتهيئة الصفرية الطرفية تؤثّر في المعاملات عند الحدود.

أمثلة محلولة (15)

مثال (3.53-1): نواة 3×3 مباشرة

المعطيات: صورة 512^2 بنواة 3×3. الحل: الخطوة 1: $2.4 \times 10^6 \approx$ عملية $\Rightarrow$ FFT لا تستحقّ (حمل النقل أكبر). النتيجة: مباشر. الربط بالذكاء الاصطناعي: لهذا تسود النوى الصغيرة في CNN.

مثال (3.53-2): نواة 64×64 عبر FFT

المعطيات: نفس الصورة بنواة كبيرة. الحل: الخطوة 1: مباشر $10^9 \approx$؛ FFT $5 \times 10^7 \approx$ $\Rightarrow$ أسرع بنحو 20 ضعفاً. النتيجة: FFT أنسب. الربط بالذكاء الاصطناعي: طبقات «conv» للنوى الكبيرة فقط.

مثال (3.53-3): مراقبة $W(\omega)$ أثناء التدريب

المعطيات: نراقب طيف نواة الطبقة الأولى. الحل: الخطوة 1: غالباً يتشكّل ككاشف حواف (تمرير عالٍ) أو تنعيم $\Rightarrow$ كمرشّحات غابور. النتيجة: الشبكة تكتشف التحليل الطيفي. الربط بالذكاء الاصطناعي: تفسيرٌ بصري لما تتعلّمه الطبقة الأولى.

مثال (3.53-4): التفاف عميق (depthwise)

المعطيات: التفافٌ لكلّ قناة على حدة. الحل: الخطوة 1: التكلفة $O(N \cdot L \cdot C)$ بدل $O(N \cdot L \cdot C^2)$ $\Rightarrow$ توفير بأضعاف. النتيجة: مرشّح لكلّ قناة. الربط بالذكاء الاصطناعي: MobileNets/EfficientNets تعتمد هذا.

مثال (3.53-5): التفاف قابل للفصل

المعطيات: نواة $D \times D$ ثنائية البعد. الحل: الخطوة 1: نقسّمها إلى $D \times 1$ ثم $1 \times D$ $\Rightarrow$ تكلفة $2D$ بدل D^2. النتيجة: توفيرٌ كبير بنفس الحقل الاستقبالي تقريباً. الربط بالذكاء الاصطناعي: convolutions separable قياسية اليوم.

مثال (3.53-6): التفاف سببي (causal)

المعطيات: نموذج صوتي لا يجوز أن «يرى» المستقبل. الحل: الخطوة 1: نستخدم عيّنات الماضي فقط $\Rightarrow$ التفاف موجّه للأمام. النتيجة: تأخيرٌ بحدّ النواة. الربط بالذكاء الاصطناعي: WaveNet والتوليد المتسلسل شرطهما السببيّة.

مثال (3.53-7): تأثير Padding على الطيف

المعطيات: padding صفري بطول كبير. الحل: الخطوة 1: يخلق قفزة عند الحدود $\Rightarrow$ مكوّنات تردّدية عالية وهمية. النتيجة: انعكاس/تمديد أفضل. الربط بالذكاء الاصطناعي: اختيار padding يؤثّر في جودة الميزات.

مثال (3.53-8): التفاف بخطوة (stride)

المعطيات: التفاف بخطوة 2. الحل: الخطوة 1: يعادل التفافاً ثم تقليل عيّنات ⇒ خطر التشويه (5.51-6). النتيجة: الترشيح قبل التقليل إلزامي. الربط بالذكاء الاصطناعي: «anti-aliased pooling» يعالجه.

مثال (3.53-9): تكلفة الذاكرة لا الحساب

المعطيات: FFT على GPU بدفعات صغيرة. الحل: الخطوة 1: عنق الزجاجة نقلُ البيانات لا العمليات ⇒ المباشر يفوز. النتيجة: قرارٌ عتادي. الربط بالذكاء الاصطناعي: هندسة الأداء تحكم تصميم الطبقات.

مثال (3.53-10): التفاف حلقي (circular) في السلاسل

المعطيات: سلسلة دورية. الحل: الخطوة 1: التفاف دوري مناسب ⇒ يطبَّق بـFFT بلا تهيئة. النتيجة: استفادة من الدورية. الربط بالذكاء الاصطناعي: الترميز الموضعي الدوري في المحوّلات.

مثال (3.53-11): التفاف متعدد القنوات ومزج الطيف

المعطيات: التفاف 1×1. الحل: الخطوة 1: لا يغيّر الزمن/المكان بل يمزج القنوات ⇒ «ترشيح» في بُعد القنوات. النتيجة: مزجٌ خطّي للميزات. الربط بالذكاء الاصطناعي: 1×1 جوهرُ عنق الزجاجة في ResNet.

مثال (3.53-12): التفاف متحوّل (transposed)

المعطيات: رفع الدقة بالتعلم. الحل: الخطوة 1: يعادل إدخال أصفار ثم التفاف ⇒ يضيف تردّدات عالية ⇒ آثار «شطرنجية». النتيجة: علاجها بترشيح أو استقراء ثم التفاف. الربط بالذكاء الاصطناعي: artfiacts checkerboard في المولّدات مشكلة طيفية.

مثال (3.53-13): قياس الحقل الاستقبالي

المعطيات: ثلاث طبقات بنواة 3 وخطوة 1. الحل: الخطوة 1: الحقل $1 + 2 \cdot 3 = 7$ ⇒ ينمو خطّيّاً بالعمق. النتيجة: CNN العميقة تحتاج كثيراً من الطبقات لسياق طويل. الربط بالذكاء الاصطناعي: مبرّرُ الالتفاف الموسّع (4.53).

مثال (3.53-14): التفاف بـFFT في التدريب

المعطيات: هل نحسب التدرّج في مجال التردّد؟ الحل: الخطوة 1: نعم — والانتشار العكسي عبر FFT ممكن (خطّية العملية). النتيجة: تدريبٌ بكفاءة FFT. الربط بالذكاء الاصطناعي: طبقات طيفية قابلة للتدريب (FNO 3.54).

مثال (15-3.53): مرشّح متعلَّم يقابل مويجة

المعطيات: نراقب نواة الطبقة الأولى على الصوت. الحل: الخطوة 1: كثيراً ما تتشكّل كمويجات غابورية بمقاييس مختلفة. النتيجة: التقاءُ التعلّم بالتحليل الكلاسيكي. الربط بالذكاء الاصطناعي: مبرّرُ استخدام قواعد مويجية ثابتة عند قلّة البيانات.

أخطاء شائعة

١. **استخدام FFT للنواة الصغيرة:** خسارة عملية.

٢. **تجاهل أن padding يضيف تردّدات وهمية:** يؤثّر في الطيف.

٣. **الخلط بين الالتفاف والترابط (correlation):** لا يهمّ مع التعلّم لكنّه يهمّ في التحليل.

٤. **نسيان أن التفاف بخطوة يشوّه:** بلا ترشيح مسبق.

٥. **الظنّ أن الحقل الاستقبالي ينمو أُسّيّاً في CNN العادية:** خطّي فقط (إلا بالتوسيع/الهرميّة).

تمهيد استفهامي

تريد شبكةً «تسمع» ثانيةً كاملة من صوت 16 kHz: هذا 16000 عيّنة. التفافٌ عادي بنواة 3 يحتاج آلاف الطبقات للوصول إلى هذا السياق! فكيف نبني حقلًا استقباليًا هائلاً بعمقٍ معقول؟

الحيلة في **التوسيع** (dilation): نترك فراغات داخل النواة. الطبقة الأولى تسمع العيّنات المتجاورة، والثانية تتخطّى 2، والثالثة 4، والرابعة 8... فينمو الحقل الاستقبالي أُسّيّاً مع العمق: $1+2(2^L-1)$. هذا بالضبط ما فعلته WaveNet لتوليد الصوت الخام، وهو — بالمناسبة — النسخة الشبكية من التحليل متعدد المقاييس الذي عرفناه في المويجات (5.52): مقاييس هندسية، لا نافذة واحدة.

صياغة رسمية

$$y[n] = \sum_{k=0}^{K-1} w_k \, x[n - d \cdot k] \tag{1.4.53}$$

(2.4.53)

$$R = 1 + (K-1)\sum_{j=0}^{L-1} 2^j = 1 + (K-1)(2^L - 1) \quad : \text{حقل استقبالي بتوسيعات } 1, 2, 4, \ldots, 2^{L-1} \text{ ونواة } K$$

(3.4.53)

$$O(N \cdot K) \text{ التعقيد: } d \text{ لكلّ طبقة — مستقل عن}$$

(4.4.53)

$$d \Rightarrow W_d(\omega) = W(d\omega) \text{ (ضغطٌ للطيف) في مجال التردّد: توسيع}$$

جدول الرموز

الرمز	المعنى	ملاحظة
d	معامل التوسيع	يحذف العيّنات بين المعاملات
K	حجم النواة	ثابت عادة
R	الحقل الاستقبالي	ينمو أُسّياً مع L
W_d	استجابة النواة الموسّعة	نسخة مضغوطة من W
L	عدد الطبقات	لوغاريتم السياق

الالتفاف الموسّع: حقلٌ استقبالي أُسّيّ

Dilated convolutions: exponential receptive field



التوسيع d=1,2,4,8,… ⇒ حقل استقبالي ينمو أُسّيّاً بعمقٍ لوغاريتمي (WaveNet).

المقابل الطيفي: تغطية مقاييس متعدّدة كما في الموجات — بلا تحويل صريح.

شكل ٢٠٥٣: *
الالتفاف الموسع: توسيعات هندسية تعطي حقلا استقباليا أسيا

برهان (مخطط)

١. **(1.4.53)** تعريف الالتفاف بخطوة داخلية d.

٢. **(2.4.53)** كلّ طبقة توسّع الحقل بمقدار $(K-1)d \Rightarrow$ مجموعٌ هندسي للتوسيعات المضاعفة.

٣. **(3.4.53)** عدد العمليات للطبقة $N \cdot K$ بغض النظر عن الفجوات.

٤. **(4.4.53)** من خاصية التحجيم في تحويل فوريه. ■

شروط الصحّة: التوسيع الكبير يخلق «ثقوباً» في التغطية ⇒ قد يفوت تفاصيل (gridding)؛ والعلاج (artfiacts) توسيعات متعدّدة متوازية أو مجموعات توسيع متضاعفة لا ثنائية فقط.

أمثلة محلولة (15)

مثال (4.53-1): حقل WaveNet النموذجي

المعطيات: $K = 2$ وتوسيعات $1, 2, \ldots, 512$ (10 طبقات). الحل: الخطوة 1: $R = 1 + (2^{10} - 1) = 1024$ عيّنة. النتيجة: سياق 64 ms عند 16 kHz بعشر طبقات فقط. الربط بالذكاء الاصطناعي: مبرّرُ كفاءة WaveNet.

مثال (4.53-2): مقارنة بالالتفاف العادي

المعطيات: نريد سياق 1024 بنواة 3 خطوة 1. الحل: الخطوة 1: عادي: 512 طبقة؛ موسّع: 10 طبقات $\Rightarrow$ توفير هائل. النتيجة: التوسيع يغيّر التركيب جذرياً. الربط بالذكاء الاصطناعي: العمق مقابل السياق قرارُ معمارية.

مثال (4.53-3): ثقوب التغطية

المعطيات: توسيع 8 بنواة 2. الحل: الخطوة 1: يرى العيّنة n و$n-8$ فقط $\Rightarrow$ يتجاهل ما بينهما. النتيجة: خطر فقدان التفاصيل المتوسطة. الربط بالذكاء الاصطناعي: التوسيعات المتوازية (ASPP) تعالجه.

مثال (4.53-4): الضغط الطيفي بالتوسيع

المعطيات: نواة تمرير منخفض موسّعة بـ4. الحل: الخطوة 1: $W(4\omega) = W_4(\omega)$ $\Rightarrow$ النطاق يضيق إلى الربع $\Rightarrow$ تكرار طيفي. النتيجة: التوسيع له أثر طيفي واضح. الربط بالذكاء الاصطناعي: التوسيع = أخذ عيّنات من الميزات (كالتقليل).

مثال (4.53-5): التوسيع في التجزئة الدلالية

المعطيات: ASPP بمعدلات 6,12,18. الحل: الخطوة 1: توسيعات متوازية تغطّي مقاييس متعدّدة بلا فقدان تغطية. النتيجة: سياق متعدد المقاييس. الربط بالذكاء الاصطناعي: DeepLab يعتمد هذه الفكرة.

مثال (4.53-6): التوسيع في الصوت الآني

المعطيات: WaveNet غير قادر على التوليد الآني (تسلسلي). الحل: الخطوة 1: التوسيع يقلّل الطبقات لكنّ التوليد يبقى تسلسلياً $\Rightarrow$ تكلفة زمنية. النتيجة: مبرّرُ البدائل المتوازية (التدفقات/WaveRNN). الربط بالذكاء الاصطناعي: التوازي مقابل السببيّة مفاضلة تصميمية.

مثال (4.53-7): التوسيع والذاكرة الطويلة

المعطيات: نحتاج سياق 10 ثوانٍ. الحل: الخطوة 1: نحتاج $\log_2(160000) \approx 18$ طبقة $\Rightarrow$ ممكن لكن عميق. النتيجة: السياق الطويل جدّاً يتطلّب بدائل (محوّلات/SSM). الربط بالذكاء الاصطناعي: الجسر إلى 6.53.

مثال (4.53-8): التكلفة ثابتة مع التوسيع

المعطيات: توسيع 1024 بنواة 2. الحل: الخطوة 1: عمليتان لكلّ عيّنة ⇒ التكلفة لا تتأثّر بـd. النتيجة: التوسيع «مجّاني» حسابيّاً. الربط بالذكاء الاصطناعي: مبرّرُ انتشار التوسيع في المعماريات.

مثال (4.53-9): التوسيع في الشبكات الزمنية (TCN)

المعطيات: TCN للسلاسل الزمنية. الحل: الخطوة 1: التفاف سببي موسّع ⇒ سياق طويل بلا تكرار ⇒ تدريب متوازٍ. النتيجة: TCN منافس قوي للRNN. الربط بالذكاء الاصطناعي: التدريب المتوازي ميزة الالتفاف على التكرار.

مثال (4.53-10): مشكلة «gridding» والحل

المعطيات: توسيعات ثنائية متتالية. الحل: الخطوة 1: ثقوب تتضخّم ⇒ نستخدم Dilated «Hybrid Convolution» بتوسيعات غير قوى اثنين. النتيجة: تغطية أكمل. الربط بالذكاء الاصطناعي: تصميمُ التوسيعات تفصيلٌ مؤثّر.

مثال (4.53-11): التوسيع في الرسوم)

المعطيات: GNN تحتاج جيراناً أبعد. الحل: الخطوة 1: «dilated aggregation» على الرسم يقابل القفزات الطيفية. النتيجة: نفس الفكرة بلا شبكة منتظمة. الربط بالذكاء الاصطناعي: توحيد المفاهيم عبر البنى.

مثال (4.53-12): التوسيع مويجياً

المعطيات: قارن بمويجات DWT. الحل: الخطوة 1: كلاهما يبني مقاييس هندسية، الأول متعلَّم والثاني متعامد. النتيجة: تفسيرٌ مشترك. الربط بالذكاء الاصطناعي: المويجات استقراءُ توسيعٍ جاهز.

مثال (4.53-13): ضبط التوسيعات للنطاق الترددي

المعطيات: إشارة بمحتوى حتى 8 kHz. الحل: الخطوة 1: التوسيعات يجب ألّا تتجاوز مقياس المحتوى وإلا فُقد ⇒ حدّ أقصى عملي. النتيجة: التوسيع مرتبط ببنية الإشارة. الربط بالذكاء الاصطناعي: فرط التوسيع يفقد التفاصيل.

مثال (4.53-14): التوسيع في الترميز الموضعي

المعطيات: ترميز موضعي بمقاييس هندسية. الحل: الخطوة 1: نفس منطق التوسيع: مقاييس متعدّدة جاهزة. النتيجة: استقراءٌ مشترك. الربط بالذكاء الاصطناعي: NeRF والمحوّلات تستخدم المقاييس الهندسية.

مثال (15-4.53): حدود الالتفاف الموسّع

المعطيات: نحتاج سياقاً غير محدّد (ذاكرة طويلة جدّاً). الحل: الخطوة 1: الالتفاف مهما توسّع له حقل ثابت ⇒ الذاكرة غير المحدودة تحتاج تكراراً. (SSM/RNN) النتيجة: الجسر إلى 6.53. الربط بالذكاء الاصطناعي: لا معمارية واحدة لكلّ السياقات.

أخطاء شائعة

١. **الظنّ أن التوسيع يزيد التكلفة:** ثابتة تقريباً.

٢. **تجاهل ثقوب التغطية:** تفاصيل مفقودة بين العيّنات.

٣. **توسيعات أكبر من مقياس المحتوى:** فقدان للمعلومات.

٤. **الخلط بين الحقل الاستقبالي وطول الذاكرة:** الأول محدود والثاني غير محدود في النماذج التكرارية.

٥. **استخدام توسيعات ثنائية فقط بلا تفكير:** HDC أفضل في كثير من الحالات.

تمهيد استفهامي

المحوّل يقرأ الجملة كلّها دفعةً واحدة: كلّ رمزٍ «ينظر» إلى كلّ رمز. ذلك سرّ قوّته — وهو سرّ تكلفته: مصفوفة انتباه $n \times n$ تعني $O(n^2)$. فسياق 4096 رمز = 16 مليون خليّة؛ وسياق 100 ألف = عشرة مليارات: مستحيل.

فكيف نتعامل مع إشاراتٍ طويلة (ساعة صوت، أو فيديو، أو سلسلة مالية)؟ ثلاثة مسارات: **تقريب الانتباه** (متفرّق/منخفض الرتبة/نووي)، أو **استبداله** بنماذج الحالة (6.53)، أو **الذهاب إلى التردّد**: مزجٌ بـFFT يعطي اتصالاً عالمياً بتكلفة $O(n \log n)$ **بلا أيّ معاملات للمزج** — وهذا هو FNet التي رأيناها في (4.8.51). والدرس الطيفي واضح: المزج العالمي لا يحتاج انتباهاً، يكفيه تحويلٌ خطّي يحفظ الطاقة.

صياغة رسمية

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right)V, \qquad \text{التكلفة: } O(n^2 d) \tag{1.5.53}$$

$$\text{انتباه خطّي (kernel): } \big(\phi(Q)\phi(K)^\top\big)V = \phi(Q)\big(\phi(K)^\top V\big) \Rightarrow O(nd^2) \tag{2.5.53}$$

$$\text{مزج فوريه (FNet): } y = \mathcal{F}^{-1}\big(R \odot \mathcal{F}(x)\big) \Rightarrow O(n \log n\, d) \tag{3.5.53}$$

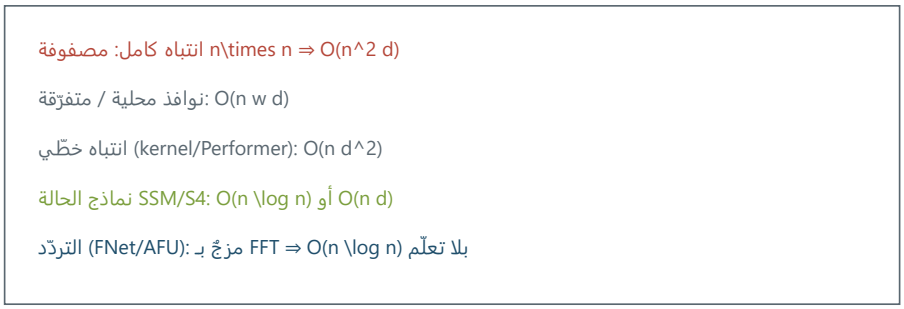
$$\text{نوافذ محلية + عالمية (Longformer/BigBird): } O(n(w+r+s)) \tag{4.5.53}$$

جدول الرموز

الرمز	المعنى	ملاحظة
Q, K, V	الاستعلام والمفتاح والقيمة	مصفوفات الرموز
n	طول السياق	مربّع التكلفة في (1.5.53)
ϕ	ميزات النواة للانتباه الخطّي	تقريب للأسّي
R	أوزان المزج الطيفي	متعلَّمة أو ثابتة
w, r, s	نافذة محلية، عشوائي، عام	في الانتباه المتفرّق

الطويل وبدائله on تعقيد الانتباه

Attention complexity O(n²) and alternatives



السياق الطويل: المفاضلة بين الدقّة (انتباه كامل) والتكلفة (بدائل أُسّيّة/طيفية).

ميزة البدائل الطيفية: مزجٌ عالمي للرموز بتكلفة FFT وبلا معاملات.

شكل ٣.٥٣: *
تعقيد الانتباه التربيعي وبدائله من النوافذ إلى المزج الطيفي

برهان (مخطط)

١. **(1.5.53)** مصفوفة الانتباه $n \times n$ من $QK^\top \Rightarrow$ تكلفة تربيعية.

٢. **(2.5.53)** إعادة ترتيب الضربات (تجميعيّة الضرب) $\Rightarrow$ لا نكوّن المصفوفة صراحةً $\Rightarrow$ خطّي في n.

٣. **(3.5.53)** FFT ثم ضربٌ عنصري ثم عكس $\Rightarrow$ مزج عالمي بلا مصفوفة n^2.

٤. **(4.5.53)** الانتباه المتفرّق يجمع ثلاثة أنماط $\Rightarrow$ خطّي في n بثوابت. ■

شروط الصحّة: البدائل تقارب الانتباه الكامل؛ والفقد يعتمد على المهمة (المهام التي تحتاج «مطابقة دقيقة» تتأثّر أكثر). والمزج الطيفي لا يتعلّم «مَن ينظر إلى مَن» — فهو استقراء ثابت.

أمثلة محلولة (15)

مثال (53.5-1): تكلفة سياق 4096

المعطيات: $n = 4096$ و$d = 512$. الحل: الخطوة 1: $n^2 d \approx 8.6 \times 10^9$ عملية لكلّ رأس $\Rightarrow$ غير مجّاني. النتيجة: الحاجة لبدائل. الربط بالذكاء الاصطناعي: سببُ سباق «السياق الطويل».

مثال (53.5-2): الانتباه الخطّي يوفر

المعطيات: نفس الأعداد بـ(53.5.2). الحل: الخطوة 1: $nd^2 \approx 1.1 \times 10^9 \Rightarrow$ أرخص بنحو 8 أضعاف. النتيجة: توفيرٌ ملحوظ بلا مصفوفة n^2. الربط بالذكاء الاصطناعي: Performer/Linear Transformers.

مثال (53.5-3): FNet بلا انتباه

المعطيات: طبقة مزج فوريه بدل الانتباه. الحل: الخطوة 1: $O(n \log n)$ وصفر معاملات للمزج $\Rightarrow$ أسرع وأصغر. الخطوة 2: الدقة تنخفض قليلاً على GLUE. النتيجة: مقايضة ممتازة لبعض المهام. الربط بالذكاء الاصطناعي: يثبت أنّ «المزج» أهمّ من «الانتباه الموجّه» أحياناً.

مثال (53.5-4): النوافذ المحلية لا تكفي وحدها

المعطيات: مهمة تعتمد على ارتباط بعيد. الحل: الخطوة 1: النافذة المحلية تفقد الارتباط البعيد $\Rightarrow$ نضيف رموزاً عامة (global tokens). النتيجة: هجين محلي/عالمي. الربط بالذكاء الاصطناعي: Longformer/BigBird.

مثال (53.5-5): الانتباه في الصوت

المعطيات: 30 ثانية صوت بـ16 kHz $\Rightarrow$ 480 ألف عيّنة. الحل: الخطوة 1: انتباه مباشر مستحيل $\Rightarrow$ نضغط أولاً (log-mel) بخطوة 10 ms $\Rightarrow$ 3000 إطار). النتيجة: الضغط الطيفي يجعل الانتباه ممكناً. الربط بالذكاء الاصطناعي: سببُ أنّ معظم نماذج الصوت تعمل على الإطارات لا العيّنات.

مثال (53.5-6): الانتباه المتفرّق بـdisالطيف

المعطيات: مصفوفة انتباه قريبة من منخفضة الرتبة. الحل: الخطوة 1: تقريب برتبة منخفضة $\Rightarrow$ خطأ يُحسب بالقيم الذاتية المهملة. النتيجة: معيارٌ كمّي للتقريب. الربط بالذكاء الاصطناعي: صلةٌ بـSVD (الفصل 4) وبتقليل الرتبة (LoRA).

مثال (5.53-7): الانتباه والالتفاف معاً ((Conformer)

المعطيات: نموذج صوت يجمع الاثنين. الحل: الخطوة 1: الالتفاف يلتقط المحلي؛ والانتباه العالمي ⇒ الأفضل للمهام الصوتية. النتيجة: هجينة رابحة. الربط بالذكاء الاصطناعي: Conformer معمارية قياسية في ASR.

مثال (5.53-8): التكلفة مقابل التعميم

المعطيات: بديل أرخص بدقة أقل. الحل: الخطوة 1: المفاضلة تُحسب على ميزانية ثابتة: نموذج أرخص ⇒ بيانات أكثر أو طبقات أكثر. النتيجة: المقارنة العادلة بالميزانية لا بالدقة وحدها. الربط بالذكاء الاصطناعي: منهجية تقييم سليمة.

مثال (5.53-9): الانتباه بوصفه مرشّحاً متكيّفاً

المعطيات: انتباه على إشارة زمنية. الحل: الخطوة 1: أوزان softmax تختار «أيّ اللحظات» ⇒ مرشّح متكيّف بالمحتوى غير خطّي. النتيجة: تجاوزٌ لحدود المرشّح الخطّي (5.53-2-14). الربط بالذكاء الاصطناعي: الانتقائيّة مصدر قوة المحوّلات.

مثال (5.53-10): الاستقراء الطيفي في الانتباه

المعطيات: ترميز موضعي جيبي. الحل: الخطوة 1: يوفّر «مقياساً» للمسافات ⇒ يسهّل تعلّم الارتباطات الموضعية والبعيدة. النتيجة: استقراءٌ رخيص وفعّال. الربط بالذكاء الاصطناعي: RoPE وALiBi تحسّنات على الفكرة نفسها.

مثال (5.53-11): تسريع بالعتاد لا بالخوارزمية

المعطيات: انتباه $O(n^2)$ محسوب بكفاءة (FlashAttention). الحل: الخطوة 1: تحسينُ حركة الذاكرة ⇒ تسريع 2–4 أضعاف بلا تغيير التعقيد. النتيجة: الهندسة تغيّر الثوابت. الربط بالذكاء الاصطناعي: الثوابت تهمّ بقدر الـO.

مثال (5.53-12): سياق طويل جدّاً

المعطيات: مليون رمز. الحل: الخطوة 1: لا انتباه كامل؛ الحلول: هرميّة، أو تكرار، أو استرجاع، أو SSM. النتيجة: لا حلّ واحد. الربط بالذكاء الاصطناعي: مجال بحث نشط (و5.54x).

مثال (5.53-13): تقييم البدائل على الصوت الطويل

المعطيات: تسجيل ساعة. الحل: الخطوة 1: نقسّم المقاطع ونستخدم SSM أو انتباهاً متفرّقاً على مستوى المقاطع. النتيجة: هرميّة زمنية. الربط بالذكاء الاصطناعي: المعالجة الهرمية للزمن (كما في المويجات).

مثال (14-5.53): مزج طيفي متعلَّم

المعطيات: R في (3.5.53) قابل للتعلّم. الحل: الخطوة 1: يصير مرشّحاً عالمياً متعلَّماً في مجال التردّد ⇒ مرونة أكبر من FNet الثابتة. النتيجة: تطويرٌ طبيعي. الربط بالذكاء الاصطناعي: يمهّد لـFNO (3.54).

مثال (15-5.53): متى يكون الانتباه الكامل ضرورياً؟

المعطيات: مهمة استرجاع دقيق (needle a in haystack). الحل: الخطوة 1: البدائل المتفرّقة قد تفوت «الإبرة» ⇒ الانتباه الكامل أدقّ. النتيجة: الاختيار بحسب المهمة مرة أخرى. الربط بالذكاء الاصطناعي: لا معمارية متفوّقة عالمياً.

أخطاء شائعة

١. **مقارنة البدائل بالدقة وحدها:** الميزانية تهمّ.

٢. **تجاهل أن الضغط الطيفي يحلّ كثيراً من مشكلة الطول:** (log-mel قبل الانتباه).

٣. **الظنّ أن المزج الطيفي يعادل الانتباه:** هو استقراء ثابت لا موجّه بالمحتوى.

٤. **نسيان أهمية الترميز الموضعي:** بدونه «حقيبة رموز» بلا ترتيب.

٥. **التركيز على O ونسيان الثوابت والعتاد:** الفرق عملياً كبير.

تمهيد استفهامي

المحوّل قوي لكنّه تربيعي، والالتفاف رخيص لكنّ ذاكرته محدودة، وRNN ذاكرته غير محدودة لكنّ تدريبه متسلسل ويعاني من التلاشي. هل يمكن أن نجمع المزايا: **ذاكرة طويلة + تدريب متوازٍ + تكلفة لوغاريتمية؟**

الجواب الحديث: **نماذج الحالة المنظّمة** (SSM)، وخصوصاً S4. الفكرة: نعود إلى معادلة تفاضلية خطّية للزمن المتّصل، ثم نحوّلها إلى التفاف طويل يمكن حسابه بـFFT — فنجني التدريب المتوازي (كالالتفاف) مع ذاكرة طويلة (كتكرار). والسرّ كله في **تهيئة المصفوفة** A: توزيعٌ مخصوص للأقطاب يسمّى HiPPO يمنح النموذج ذاكرةً لامتناهية المدى «جاهزة» قبل أيّ تعلّم.

وهذا يغلق الدائرة مع الفصل 49: **الأقطاب تحدّد الذاكرة** — القاعدة التي كتبناها في (5.6.49) للمرشّحات تعمل هنا لنماذج التعلّم العميق.

صياغة رسمية

$$h'(t) = Ah(t) + Bx(t), \qquad y(t) = Ch(t) \tag{1.6.53}$$

(ثنائي) $\bar{A} = (I - \Delta A/2)^{-1}(I + \Delta A/2)$, $h_n = \bar{A}h_{n-1} + \bar{B}x_n$ (بخطوة Δ بالتفريد): (2.6.53)

$$y_n = \sum_{k=0}^{n} \bar{K}_k \, x_{n-k}, \qquad \bar{K}_k = C\bar{A}^k\bar{B} \Rightarrow \text{ يُحسب بـFFT } O(N \log N) \tag{3.6.53}$$

كنواة التفاف:

$$A_{nk} = -\begin{cases} (2n+1)^{1/2}(2k+1)^{1/2}, & n > k \\ n+1, & n = k \\ 0, & n < k \end{cases} \tag{4.6.53}$$

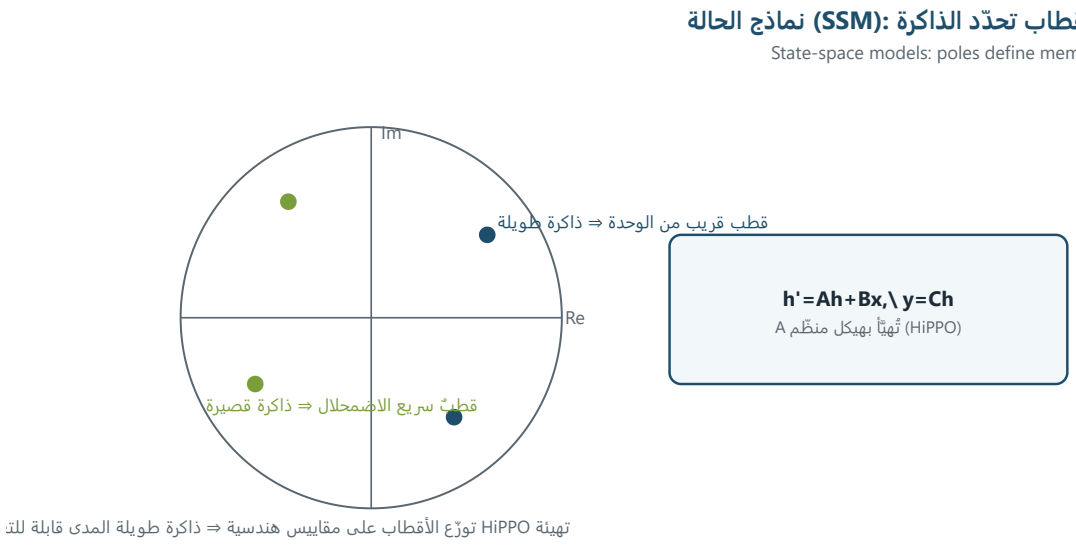
HiPPO: تهيئة

$$\tau \approx \frac{1}{1-\rho} \qquad \rho(\bar{A}) < 1, \tag{5.6.53}$$

زمن الذاكرة والاستقرار:

جدول الرموز

الرمز	المعنى	ملاحظة
A, B, C	مصفوفات الحالة والدخل والخراج	قلب SSM
Δ	خطوة التفريد	معلومةٌ مهمة تُتعلَّم
$\bar{A}, \bar{B}$	النسخ المفرّدة	للتنفيذ المنفصل
$\bar{K}$	نواة الالتفاف المكافئة	طولها = السياق
HiPPO	تهيئة الضغط التاريخي	مقاييس هندسية للذاكرة



شكل ٤٠٥٣: *
نماذج الحالة: مواقع الأقطاب تحدد طول الذاكرة وتهيئة HiPPO

برهان (مخطط)

١. **(1.6.53)** صياغة نظام خطّي ثابت في الزمن المتّصل.

٢. **(2.6.53)** تفريد ثنائي (bilinear) يحفظ الاستقرار (يُداخل نصف المستوي الأيسر داخل دائرة الوحدة).

٣. **(3.6.53)** بتكرار (2.6.53) نحصل على التفاف بنواة $\bar{K}_k$؛ وحسابه بـFFT (لأنّه التفاف طويل).

٤. **(4.6.53)** HiPPO مشتقّ من إسقاط التاريخ على متعدّدات متعامدة $\Rightarrow$ أقطاب بمقاييس هندسية (مويجية الطابع!).

٥. **(5.6.53)** معدّل الاضمحلال $\rho - 1$ يعطي زمن الذاكرة المميّز. ■

شروط الصحّة: الاستقرار يتطلّب $\rho(\bar{A}) < 1$؛ والتهيئة العشوائية لـA تعطي ذاكرة قصيرة — ومن هنا جاءت أهمية الهيكل المنظّم (diagonal) low-rank, plus (DPLR) الذي يجعل حساب النواة ممكناً.

أمثلة محلولة (15)

مثال (1-6.53): لماذا التهيئة العشوائية تفشل

المعطيات: A عشوائية بـ$\rho = 0.5$. الحل: الخطوة 1: $\tau \approx 2$ خطوة $\Rightarrow$ ذاكرة قصيرة جدّاً. النتيجة: النموذج «ينسى» فوراً. الربط بالذكاء الاصطناعي: سببُ فشل RNN العادية في المهام الطويلة.

مثال (2-6.53): أثر HiPPO

المعطيات: أقطاب بمقاييس $1, 2, 4, \ldots$ بمعدّلات اضمحلال هندسية. الحل: الخطوة 1: أقطاب قريبة من الوحدة $\Rightarrow$ ذاكرة طويلة؛ وأخرى بعيدة $\Rightarrow$ تفاصيل قريبة. النتيجة: ذاكرة متعددة المقاييس. الربط بالذكاء الاصطناعي: التهيئة = استقراء طيفي مجّاني.

مثال (3-6.53): التفريد يحفظ الاستقرار

المعطيات: $a = -1$ و$\Delta = 0.5$. الحل: الخطوة 1: $\bar{a} = \frac{1+\Delta a/2}{1-\Delta a/2} = \frac{0.75}{1.25} = 0.6 \Rightarrow |\bar{a}| < 1$ ✓. النتيجة: التفريد الثنائي آمن. الربط بالذكاء الاصطناعي: التفريد الخاطئ يفسد التدريب — تفصيلٌ حاسم.

مثال (4-6.53): نواة الالتفاف المكافئة

المعطيات: A قطرية بقيم $0.9, 0.5$ و$B = C = 1$. الحل: الخطوة 1: $\bar{K}_k = 0.9^k + 0.5^k \Rightarrow$ نواة طويلة باضمحلالين. النتيجة: التفافٌ بمقياسين. الربط بالذكاء الاصطناعي: SSM = التفاف بمقاييس متعدّدة متعلَّمة.

مثال (5-6.53): التكلفة

المعطيات: $N = 10^5$ عيّنة. الحل: الخطوة 1: نواة طولها N تُطبَّق بـFFT $\Rightarrow O(N \log N)$ بدل $O(N^2)$. النتيجة: تدريبٌ متوازٍ ممكن. الربط بالذكاء الاصطناعي: ميزة SSM على RNN في التدريب.

مثال (6-6.53): الاستدلال التكراري

المعطيات: توليدٌ متسلسل. الحل: الخطوة 1: نستخدم (2.6.53) ⇒ تكلفة ثابتة لكلّ خطوة (بخلاف المحوّل المتضخّم الذاكرة). النتيجة: كفاءة الاستدلال. الربط بالذكاء الاصطناعي: ميزة SSM على المحوّل في السياقات الطويلة.

مثال (7-6.53): العلاقة بالمرشّح IIR

المعطيات: SSM ببعد حالة 1. الحل: الخطوة 1: $\bar{a}$ هو قطب المرشّح ⇒ SSM تعميمٌ لـIIR متعدد الأبعاد. النتيجة: النظرية واحدة. الربط بالذكاء الاصطناعي: يربط الفصل 49 بـ53 مباشرة.

مثال (8-6.53): اختيار Δ

المعطيات: إشارة بمحتوى سريع. الحل: الخطوة 1: Δ كبير ⇒ يفقد التفاصيل؛ وصغير ⇒ ذاكرة أقصر بالخطوات. النتيجة: Δ معلومةٌ حسّاسة تُعلَّم. الربط بالذكاء الاصطناعي: Δ يشبه «دقة العيّنة» الداخلية للنموذج.

مثال (9-6.53): أقطاب مركّبة وتذبذب

المعطيات: أزواج أقطاب مركّبة. الحل: الخطوة 1: تعطي ذاكرة متذبذبة ⇒ مفيدة للإشارات الدورية. النتيجة: طيفٌ أغنى. الربط بالذكاء الاصطناعي: صلةٌ بتحويل فوريه (الأقطاب على دائرة الوحدة = تردّدات).

مثال (10-6.53): البنية القطرية زائد منخفضة الرتبة (DPLR)

المعطيات: نحتاج حساباً سريعاً للنواة. الحل: الخطوة 1: $A = \Lambda - PQ^{\top}$ ⇒ حساب النواة بصيغة «Cauchy kernel» ⇒ $O(N \log N)$. النتيجة: هذا هو إنجاز S4 التقني. الربط بالذكاء الاصطناعي: هندسة رياضية دقيقة وراء نجاح معماري.

مثال (11-6.53): مقارنة SSM بالمحوّل

المعطيات: سياق 64 ألف رمز. الحل: الخطوة 1: المحوّل $O(n^2)$ غير ممكن؛ وSSM $O(n \log n)$ ممكن. النتيجة: مبرّرُ الاهتمام البحثي الكبير. الربط بالذكاء الاصطناعي: Mamba/S4 منافسة المحوّلات في السياقات الطويلة.

مثال (12-6.53): الانتقائيّة (selective SSM / Mamba)

المعطيات: نريد أن «يختار» النموذج ما يتذكّره. الحل: الخطوة 1: نجعل B, C, Δ دوالّ في المدخل ⇒ انتقائيّة بالمحتوى. النتيجة: أداءٌ أعلى؛ والتكلفة: لا التفاف ثابت ⇒ حاجة لتقنية مسح متوازٍ. الربط بالذكاء الاصطناعي: Mamba أحدث تطوير لهذه الفكرة.

مثال (53.6-13): الذاكرة الطويلة قياساً

المعطيات: $\rho = 0.999$ بخطوة 1. الحل: الخطوة 1: $\tau \approx 1000$ خطوة $\Rightarrow$ ذاكرة ألفية. النتيجة: القرب من الوحدة يطيل الذاكرة ويقارب عدم الاستقرار. الربط بالذكاء الاصطناعي: مفاضلة الذاكرة مقابل الاستقرار (كما في المرشّحات).

مثال (53.6-14): تطبيق على السلاسل الطويلة جدّاً

المعطيات: سلسلة من مليون نقطة. الحل: الخطوة 1: SSM بمسح متوازٍ $\Rightarrow$ تدريب ممكن بذاكرة معقولة $\Rightarrow$ نتائج متفوّقة على المحوّلات. النتيجة: «Long Range» Arena شاهد. الربط بالذكاء الاصطناعي: المعايير المرجعية تحدّد المعماريات الرابحة.

مثال (53.6-15): الحدود

المعطيات: مهام استرجاع دقيق (copying). الحل: الخطوة 1: SSM الخطّية أضعف من الانتباه في «الاسترجاع الحرفي» $\Rightarrow$ حاجة للانتقائيّة أو هجائن. النتيجة: لا معمارية كاملة. الربط بالذكاء الاصطناعي: البحث يتجه إلى هجائن انتباه/حالة.

أخطاء شائعة

١. **تهيئة A عشوائياً:** ذاكرة قصيرة مضمونة.

٢. **تفريد غير حافظ للاستقرار:** انفجار.

٣. **Δ ثابت بلا تفكير:** يحدّد مقياس الزمن الداخلي.

٤. **توقّع تفوّق SSM في كلّ مهمة:** مهام الاسترجاع الدقيق لصالح الانتباه.

٥. **نسيان أن SSM مرشّح IIR متعدد الأبعاد:** النظرية القديمة تكفي لفهمه.

تمهيد استفهامي

لدينا طيفٌ (log-mel) ونريد موجةً نسمعها. المشكلة أنّ الطيف فقد **الطور** — ونصف المعلومات ذهب. الطرق الكلاسيكية تقدّر الطور تكرارياً (Grffiin–Lim) بجودة متواضعة؛ أمّا الشبكات فتتعلّم توليد الموجة مباشرةً: WaveNet عيّنةً بعيّنة، وHiFi-GAN بمولّد تلافيفي، ونماذج الانتشار بتكرارٍ مضبوط.

والسؤال الهندسي العملي: كيف نحكم على الجودة؟ مقاييسُ الزمن (MSE على الموجة) ضعيفة الارتباط بالإدراك؛ لذا نستخدم مقاييس طيفية (فقدانٌ متعدد المقاييس على الطيف، وتقييمات إدراكية). والدرس الأوسع: **الموجة تُقيَّم في مجال التردّد** — لأنّ الأذن كذلك تفعل.

صياغة رسمية

$$p(x) = \prod_{t=1}^{T} p\big(x_t \mid x_{<t}, c\big), \qquad c = \text{(طيف/نص) شرط} \tag{1.7.53}$$ توليد تلقائي:

$$\min_G \max_D \; \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(c)))] \tag{2.7.53}$$ فقدان المولّد (GAN):

$$\mathcal{L}_{\text{mel}} = \sum_{s} \big\| \phi_s(x) - \phi_s(\hat{x}) \big\|_1 \tag{3.7.53}$$ فقدان طيفي متعدد المقاييس:

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \Big(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(x_t, t) \Big) \tag{4.7.53}$$ الانتشار على الإشارة:

جدول الرموز

الرمز	المعنى	ملاحظة
c	شرط التوليد	طيف أو نص أو هوية متكلّم
x_t	العيّنة عند الزمن t	في الصوت: العيّنة الزمنية
ϕ_s	تحليل طيفي بمقياس s	يركّز على مقاييس مختلفة
D, G	المميّز والمولّد	في HiFi-GAN/MelGAN
ϵ_θ	شبكة تقدير الضجيج	في الانتشار

من الطيف إلى الموجة: المُرمِّز الصوتي العصبي

Neural vocoder: spectrum → waveform



التحدّي: إعادة بناء الطور (phase) المفقود في الطيف — إمّا تعلمه، وإما تقديره (n الانتشار على الإشارات يولّد الطور مباشرةً ويبدع عيّنات عالية الدقّة.

شكل ٥.٥٣: *
المُرمِّز الصوتي العصبي: من الطيف إلى الموجة عبر شبكة توليدية

برهان (مخطط)

١. **(1.7.53)** قاعدة السلسلة على التوزيع المشترك ⇒ نمذجة تلقائية (autoregressive).

٢. **(2.7.53)** صيغة min-max لـGAN (الفصل 41) مطبّقة على الموجة.

٣. **(3.7.53)** بدل مقارنة الموجات نقارن أطيافها بمقاييس متعدّدة ⇒ ارتباط أفضل بالإدراك.

٤. **(4.7.53)** صيغة أخذ العيّنات العكسي للانتشار (الفصل 41) على الإشارة. ■

شروط الصحّة: النماذج التلقائية بطيئة الاستدلال (عيّنة بعيّنة)؛ وGAN أسرع لكنّ تدريبها أصعب؛ والانتشار أبطأ لكنّه أعلى جودة. والمقاييس الموضوعية لا تغني عن التقييم الإدراكي.

أمثلة محلولة (15)

مثال (1-7.53): لماذا الطور مهم

المعطيات: طيفان متطابقا المطال وأطوار مختلفة. الحل: الخطوة 1: الموجتان مختلفتان تماماً ⇒ الطور حامل البنية الزمنية. النتيجة: فقدان الطور مشكلة جوهريّة. الربط بالذكاء الاصطناعي: كلّ نموذج «من الطيف» يجب أن يتعلّم الطور.

مثال (2-7.53): Griffin–Lim

المعطيات: طيف المطال فقط. الحل: الخطوة 1: تكرار: STFT ⇒ طور محسوب ⇒ موجة ⇒ STFT ⇒ استبدال المطال ⇒ ... النتيجة: تقديرٌ تقريبي بجودة متواضعة. الربط بالذكاء الاصطناعي: مرجعٌ كلاسيكي تقاس عليه الشبكات.

مثال (3-7.53): WaveNet عيّنةً بعيّنة

المعطيات: 24 kHz ⇒ 24000 توقّع في الثانية. الحل: الخطوة 1: تكلفة هائلة ⇒ غير عملي للزمن الحقيقي في بداياته. النتيجة: مبرّرُ البدائل المتوازية. الربط بالذكاء الاصطناعي: التوازي مطلبٌ صناعي لا نظري.

مثال (4-7.53): HiFi-GAN

المعطيات: مولّد تلافيفي + مميّزات متعددة المقاييس. الحل: الخطوة 1: يولّد الموجة دفعةً ⇒ أسرع بمئات المرات من WaveNet بجودة أعلى. النتيجة: معيارٌ صناعي للمُرمِّزات. الربط بالذكاء الاصطناعي: GAN ما زالت الأفضل في جودة/سرعة الصوت.

مثال (5-7.53): مميّزات متعددة المقاييس

المعطيات: نريد أن يحكم المميّز على التفاصيل والمقاييس الكبيرة. الحل: الخطوة 1: مميّزات على مستويات دقة مختلفة ⇒ تغطية طيفية أوسع. النتيجة: جودة أعلى بصرياً وسمعياً. الربط بالذكاء الاصطناعي: تعدد المقاييس مبدأٌ متكرّر

في هذا الكتاب.

مثال (53.7-6): فقدان طيفي متعدد المقاييس

المعطيات: مقارنة الموجتين مباشرة. الحل: الخطوة 1: MSE على الموجة يعاقب إزاحة طفيفة بشدة ⇒ مقاييس الطيف أعدل. النتيجة: اختيارُ مقياس الفقدان قرارُ جودة. الربط بالذكاء الاصطناعي: تصميمُ الخسارة = تصميمُ المقياس (8.3/51.53).

مثال (53.7-7): التوليد الشرطي من النص

المعطيات: نص ⇒ طيف ⇒ موجة (TTS حديث). الحل: الخطوة 1: مرحلتان أو ⇒ جودة شبه بشرية. النتيجة: نضجٌ صناعي. الربط بالذكاء الاصطناعي: تطبيقٌ مباشر للنماذج التوليدية (الفصل 41).

مثال (53.7-8): الانتشار على الصوت

المعطيات: توليد موسيقى/كلام بانتشار. الحل: الخطوة 1: تكرار إزالة الضجيج على الموجة أو الطيف ⇒ جودة عالية وتنوّع. النتيجة: الجودة مقابل السرعة. الربط بالذكاء الاصطناعي: اتجاهٌ حديث في توليد الصوت.

مثال (53.7-9): التقييم الإدراكي (MOS)

المعطيات: نموذجان بنتائج موضوعية متقاربة. الحل: الخطوة 1: اختبار بشري (MOS) ⇒ الحكم النهائي. النتيجة: المقاييس الموضوعية مرشّح أولي لا نهائي. الربط بالذكاء الاصطناعي: التقييم البشري يبقى المعيار في الإدراكيات.

مثال (53.7-10): التشويش الطيفي في المولّدات

المعطيات: artfiacts عالية التردّد في الموجة المولّدة. الحل: الخطوة 1: تظهر «طنيناً» ⇒ علاجها بمميّز طيفي أو تهيئة أفضل. النتيجة: artfiacts تُشخَّص طيفياً. الربط بالذكاء الاصطناعي: التحليل الطيفي أداةُ تشخيص النماذج.

مثال (53.7-11): التحكم في النبرة والسرعة

المعطيات: نريد تعديل النبرة بلا تغيير الهوية. الحل: الخطوة 1: تعديلٌ في مجال الطيف (تحويل المقاييس) ⇒ إعادة بناء بالمُرمِّز. النتيجة: تحكمٌ قابل للتفسير. الربط بالذكاء الاصطناعي: التلاعب بالمجال الطيفي أسهل من الموجة.

مثال (53.7-12): ضغط الكلام العصبي

المعطيات: معدّل بتّات منخفض جداً (5.1 kbps). الحل: الخطوة 1: مُرمِّز عصبي يتعلّم تمثيلاً مضغوطاً ⇒ جودة

أعلى من الترميز التقليدي. النتيجة: مستقبل ترميز الاتصالات. الربط بالذكاء الاصطناعي: الضغط العصبي موضوع الفصل 54.

مثال (13-7.53): استنساخ الصوت والمخاطر

المعطيات: بضع ثوانٍ من صوت شخص. الحل: الخطوة 1: نموذج يتعلّم هوية المتكلّم ⇒ إمكانية إساءة الاستخدام. النتيجة: مخاطر أخلاقية مصاحبة. الربط بالذكاء الاصطناعي: مسؤوليةُ الاستخدام جزءٌ من التصميم.

مثال (14-7.53): الذاكرة أثناء الاستدلال

المعطيات: توليد دقيقة صوت بدقة 48 kHz. الحل: الخطوة 1: 2.9×10^6 عيّنة ⇒ إدارة ذاكرة حذرة (إطارات متداخلة). النتيجة: هندسة الاستدلال. الربط بالذكاء الاصطناعي: الكفاءة جزءٌ من جودة المنتج.

مثال (15-7.53): من الموجة إلى الطيف والعكس

المعطيات: نظرة شاملة. الحل: الخطوة 1: التحليل (52) ⇒ التمثيل (6.53-5.53) ⇒ التوليد (7.53) ⇒ دائرة واحدة. النتيجة: الفصل يغلق الدائرة. الربط بالذكاء الاصطناعي: وحدةُ خط الأنابيب في أنظمة الإشارة الحديثة.

أخطاء شائعة

١. **تجاهل مشكلة الطور:** نصف المعلومات.

٢. **الاعتماد على MSE في الزمن:** لا يرتبط بالإدراك.

٣. **توقّع أن النماذج التلقائية عملية للزمن الحقيقي:** الاستدلال بطيء.

٤. **تجاهل artfiacts الطيفية في التقييم:** تُسمع وإن لم تُقَس.

٥. **نسيان البعد الأخلاقي في استنساخ الأصوات.**

تمهيد استفهامي

بيانات الصوت الموسومة مكلفة، وغير الموسومة متاحة بملايين الساعات. فكيف نستفيد؟ بفكرتين من هذا الكتاب: **تكبيرٌ في مجال التردّد** (SpecAugment: نحذف خطوطاً زمنية وترددّية من الطيف — تنظيمٌ قوي بلا تشويه للمعنى)، **وتعلّم ذاتي الإشراف** (نخفي أجزاءً من الإشارة ونطلب توقعها، أو نميّز عيّنات إيجابية عن سلبية في فضاء كامن).

كلتاهما تعمل في المجال الطيفي لا الموجي: لأنّ حذف نطاق تردّدي يشبه حذف «لون» مؤقّت، فيبقى المعنى؛ ولأنّ الفضاء الكامن الذي نتعلّمه يقابل — تحليلياً — تمثيلاً طيفياً متعدد المقاييس.

صياغة رسمية

$$\text{SpecAugment:} \tilde{S}[m,k] = S[m,k] \cdot \mathbf{1}\{m \notin [t_0, t_0+t]\} \cdot \mathbf{1}\{k \notin [f_0, f_0+f]\} \qquad (1.8.53)$$

$$\mathcal{L} = -\log \frac{\exp(\mathrm{sim}(q_t, c_t)/\kappa)}{\sum_{\tilde{c}} \exp(\mathrm{sim}(q_t, \tilde{c})/\kappa)} \quad \text{توقع مُقنَّع (MAM/wav2vec 2.0):} \tag{2.8.53}$$

$$\mathcal{L} = -\mathbb{E} \log \frac{e^{f(x)^T f(x^+)/\tau}}{e^{f(x)^T f(x^+)/\tau} + \sum_j e^{f(x)^T f(x_j^-)/\tau}} \quad \text{تناقضي (contrastive):} \tag{3.8.53}$$

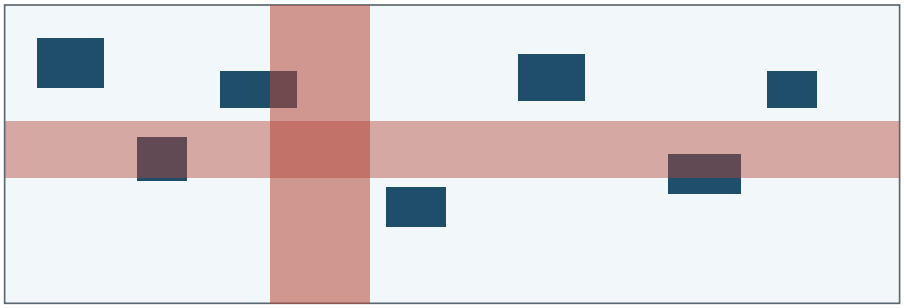
$$\hat{R}(h) \le R(h) + \text{فجوة التكبير} \quad \text{تنظيم بالتكبير:} \tag{4.8.53}$$

جدول الرموز

الرمز	المعنى	ملاحظة
t, f	طول القناع الزمني والتردّدي	معاملات التكبير
q_t, c_t	استعلام وتمثيل كامن مستهدف	في التعلّم المُقنَّع
κ, τ	حرارة المقارنة	تضبط حدّة التوزيع
x^+, x^-	إيجابية وسلبية	في التعلم التناقضي
SpecAugment	تكبير طيفي	تنظيم بلا بيانات جديدة

تكبير البيانات الطيفية (SpecAugment)

SpecAugment: time/frequency masking



قناع زمني وقناع تردّدي على الطيف — تنظيمٌ قوي بلا تغيير في المعنى.

نظيره في الصور: Cutout/Mixup؛ وفي الرسوم: حذف روابط (edge dropout).

شكل ٦.٥٣: *
تكبير البيانات الطيفية: أقنعة زمنية وترددية على الطيف

برهان (مخطط)

١. **(1.8.53)** حذفُ نطاق تردّدي يترك «المعنى» (كلمات/أحداث) سليماً ⇒ تنظيم متوافق مع المهمة.

٢. **(2.8.53)** نخفي نوافذ من الإشارة الكامنة ونطلب تصنيفها بين «مشوّشات» ⇒ يتعلّم النموذج بنيةً دلالية.

٣. **(3.8.53)** هدف InfoNCE يقارب المعلومات المتبادلة (الفصل 27) ⇒ تمثيلٌ غني.

٤. **(4.8.53)** التكبير يوسّع «دعم» التوزيع ⇐ يقلّل فجوة التعميم. ■

شروط الصحّة: التكبير يجب أن يحافظ على التسمية ؛(label-preserving) والإفراط فيه يدمّر المعلومات. والتعلّم الذاتي يحتاج عيّنات سلبية كافية أو آليات تمنع الانهيار .(collapse)

أمثلة محلولة (15)

مثال (1-8.53): إعداد SpecAugment نموذجي

المعطيات: log-mel بـ80 قناة. الحل: الخطوة 1: قناع تردّدي بعرض 27 قناة (مرّتين) وقناع زمني بطول 100 إطار. النتيجة: تحسّن ملحوظ في ASR بلا بيانات إضافية. الربط بالذكاء الاصطناعي: تنظيمٌ «مجّاني» فعّال.

مثال (2-8.53): لماذا القناع الترددّي منطقي

المعطيات: حذف نطاق 500–1000 Hz من الكلام. الحل: الخطوة 1: الكلمة تبقى مفهومة (تكرارٌ في الطيف) ⇐ التسمية محفوظة. النتيجة: تكبيرٌ متوافق مع المهمة. الربط بالذكاء الاصطناعي: التوافق مع المهمة شرطُ التكبير الناجح.

مثال (3-8.53): القناع الزمني يعادل إسقاطاً زمنياً

المعطيات: حذف 5.0 ثانية. الحل: الخطوة 1: النموذج يتعلّم ألّا يعتمد على لحظة بعينها ⇐ متانة زمنية. النتيجة: متانة للإزاحة. الربط بالذكاء الاصطناعي: نظيرُ Dropout في الزمن.

مثال (4-8.53): Mixup في الطيف

المعطيات: خلط طيفين. الحل: الخطوة 1: يمزج الترددّات خطّياً ⇐ تنظيمٌ ناعم (لا حذف). النتيجة: تحسينُ المعايرة .calibration الربط بالذكاء الاصطناعي: التنظيم الناعم مقابل الحادّ.

مثال (5-8.53): wav2vec 0.2

المعطيات: مليون ساعة غير موسومة. الحل: الخطوة 1: تمثيل كامن + إخفاء + تناقضي ثم ضبط دقيق على 10 دقائق موسومة ⇐ نتائج مذهلة. النتيجة: توفيرٌ هائل في الوسم. الربط بالذكاء الاصطناعي: نموذجٌ غيّر اقتصاديات بيانات الصوت.

مثال (6-8.53): HuBERT بالتجميع

المعطيات: لا مشوّشات جاهزة. الحل: الخطوة 1: نجمّع المعاملات الكامنة ⇐ أهداف «تسميات مخفية» ⇐ توقّعها. النتيجة: تعلّمٌ ذاتي بلا تصميم يدوي للمشوّشات. الربط بالذكاء الاصطناعي: فكرة التجميع الذاتي (كما في تجميع

النصوص).

مثال (8.53-7): التمثيل الكامن طيفياً

المعطيات: نحلّل طيف المعاملات الكامنة. الحل: الخطوة 1: الطبقات الأولى تحمل تفاصيل صوتية (عالية التردّد) والأخيرة دلالية (منخفضة). النتيجة: هرميّة طيفية في التمثيل. الربط بالذكاء الاصطناعي: تحليلٌ طيفي لما تتعلّمه الشبكة.

مثال (8.53-8): منع الانهيار (collapse)

المعطيات: هدف تناقضي بلا عيّنات سلبية كافية. الحل: الخطوة 1: كلّ العيّنات تتطابق ⇒ تمثيل ثابت ⇒ لا تعلّم. الخطوة 2: العلاج: عيّنات سلبية كثيرة، أو معايرة تباين (VICReg/Barlow). النتيجة: تصميمُ الهدف حاسم. الربط بالذكاء الاصطناعي: درسٌ عام في التعلّم الذاتي (الفصلان 27 و41).

مثال (8.53-9): التكبير في المويجات

المعطيات: تكبير على معاملات مويجية. الحل: الخطوة 1: حذف معاملات بمقاييس مختارة ⇒ تكبير متعدد المقاييس. النتيجة: تنوّعٌ أوسع من SpecAugment. الربط بالذكاء الاصطناعي: يربط الفصل 52 بـ53.

مثال (8.53-10): التكبير الطيفي في الصور

المعطيات: صور طبية. الحل: الخطوة 1: حذف نطاقات تردّدية في space Fourier ⇒ متانة للتوزيعات المختلفة. النتيجة: تعميمٌ أفضل عبر المستشعرات. الربط بالذكاء الاصطناعي: «amplitude/phase augmentation» تقنية حديثة.

مثال (8.53-11): تكبير متوافق مع الفيزياء

المعطيات: إشارات حسّاسات صناعية. الحل: الخطوة 1: نضيف ضجيجاً بنمط واقعي (من قياسات فارغة) بدل ضجيج اصطناعي. النتيجة: تكبيرٌ واقعي. الربط بالذكاء الاصطناعي: التكبير يجب أن يحاكي توزيع الاختبار.

مثال (8.53-12): قياس أثر التكبير

المعطيات: نموذجان بتكبير وبغيره. الحل: الخطوة 1: نقيس على مجموعة اختبار «صعبة» (ضجيج/قنوات غير مرئية) ⇒ الفرق يتضح. النتيجة: التقييم المناسب يكشف الأثر. الربط بالذكاء الاصطناعي: اختبارات التوزيع الخارجي (OOD).

مثال (53.8-13): التكبير والتحيّز

المعطيات: تكبير يغيّر التسمية (مثلاً قلب الإشارة الطبية). الحل: الخطوة 1: يدمّر التعلّم ⇒ شرط التوافق مع التسمية إلزامي. النتيجة: ليس كلّ تحوير تكبيراً صالحاً. الربط بالذكاء الاصطناعي: معرفة المجال شرطُ تصميم التكبير.

مثال (53.8-14): التعلّم الذاتي والضغط

المعطيات: نموذج مُدرَّب ذاتياً. الحل: الخطوة 1: تمثيله يضغط الإشارة ⇒ يمكن استخدامه في الضغط العصبي (5.54). النتيجة: وحدةٌ بين التمثيل والضغط. الربط بالذكاء الاصطناعي: كما في نظرية المعلومات (الجزء الخامس).

مثال (53.8-15): حدود البيانات غير الموسومة

المعطيات: بيانات غير موسومة بتوزيع مختلف عن المهمة. الحل: الخطوة 1: التمثيل المتعلَّم قد يكون غير مناسب ⇒ تدهور محتمل. النتيجة: جودةُ «ما قبل التدريب» شرط. الربط بالذكاء الاصطناعي: توافقُ التوزيع يحكم نقل التعلّم.

أخطاء شائعة

١. **تكبير يغيّر التسمية:** يدمّر الأداء.

٢. **قناع تردّدي أوسع من اللازم:** يفقد محتوى المهمة.

٣. **عيّنات سلبية قليلة ⇒ انهيار:** في الأهداف التناقضية.

٤. **اعتبار التعلّم الذاتي حلاً سحرياً لكلّ نقص البيانات:** التوزيع يهمّ.

٥. **قياس الأثر على بيانات التدريب فقط:** لا يكشف المتانة.

تمارين (30)

مستوى أول:

١. احسب $H(z)$ لمرشّح FIR بمعاملات $(1,2,1)/4$ واستنتج $|H|$ عند $\omega = 0, \pi/2, \pi$.

٢. تحقّق من استقرار IIR بأقطاب 0.9 و-0.8.

٣. احسب طول FIR لانتقال نسبي 0.01.

٤. احسب حقل الاستقبال لـ$K = 3$ وعشر طبقات بتوسيعات ثنائية.

٥. احسب تكلفة انتباه لـ$n = 8192$ و$d = 768$.

٦. احسب تكلفة المزج الطيفي للعدد نفسه.

٧. احسب $\bar{a}$ لتفريد ثنائي بـ$a = -2$ و$\Delta = 0.1$.

٨. احسب زمن الذاكرة لـ$\rho = 0.995$ بالخطوات.

٩. احسب عدد عيّنات دقيقة صوت بدقة 48 kHz.

١٠. اكتب SpecAugment على طيف 300×80.

مستوى ثان:

١. برهن (3.2.53) شرط الاستقرار من تحليل الأقطاب.

٢. برهن أن FIR المتماثل يعطي طوراً خطّياً.

٣. اشتقّ حقل الاستقبال الأُسّي في (2.4.53).

٤. برهن (2.5.53) خطّية الانتباه بإعادة ترتيب الضرب.

٥. اشتقّ نواة الالتفاف المكافئة لـSSM (3.6.53).

٦. برهن أن التفريد الثنائي يُداخل نصف المستوي الأيسر داخل دائرة الوحدة.

٧. قارن تكلفة WaveNet وHiFi-GAN لتوليد ثانية صوت.

٨. برهن أن (3.8.53) يقارب حداً أدنى للمعلومات المتبادلة.

٩. اشرح كيف يمنع SpecAugment الاعتماد على نطاق تردّدي واحد.

١٠. صغ العلاقة بين SSM ومرشّح IIR بصيغة موحّدة.

مستوى ثالث:

١. صمّم خطوة preprocessing لصوت 48 kHz تُنتج 80 log-mel قناة (اذكر الأرقام كلّها).

٢. صمّم SSM لذاكرة 10 آلاف خطوة: اقترح ρ والبعد والتهيئة.

٣. قارن معمارياً بين محوّل وSSM لمهمة سياق 100 ألف: جدول تكلفة وذاكرة.

٤. شخص artfiacts «طنين» في مُرمِّز عصبي واقترح علاجين طيفيّين.

٥. متى تفضّل التفافاً موسّعاً على SSM والعكس؟ علّل.

٦. صغ هدفاً ذاتيّ الإشراف لإشارات حسّاسات صناعية يحترم فيزياء القياس.

٧. اربط بين فقدانٍ طيفي متعدد المقاييس وتحليل مويجي.

٨. اشرح كيف يفسّر التحليل الطيفي نجاح «anti-aliased pooling».

٩. ناقش مفاضلة السببيّة مقابل التوازي في نماذج الإشارات.

١٠. صمّم تجربةً تقارن تكبيراً مويجياً بـSpecAugment على بياناتك.

ملخص الفصل

النظرية	الصيغة المحوريّة	الدرس العملي
FIR/IIR	$H(z) = B(z)/A(z)$، الأقطاب تحدّد الاستقرار	FIR آمن وIIR رخيص
الالتفاف المتعلَّم	$Y = WX$، تكلفة $O(NL)$ مقابل FFT	النواة الصغيرة مباشرة
التوسيع	$R = 1 + (K-1)(2^L - 1)$	سياق أُسّي بعمق لوغاريتمي
الانتباه وبدائله	$O(n^2 d)$ مقابل $O(n \log n)$	المزج الطيفي يكفي أحياناً
SSM/S4	$h' = Ah + Bx$ بتهيئة HiPPO	الأقطاب = الذاكرة
المُرمِّزات	من الطيف إلى الموجة بشرط	الطور نصف المعلومات
التكبير والتعلّم الذاتي	SpecAugment وInfoNCE	تنظيمٌ بلا بيانات جديدة

الجسر إلى الفصل 54: كلّ ما سبق افترض إشارةً على شبكة منتظمة (زمن أو صورة). فماذا لو كانت الإشارة على رسم؟ وما إذا كنّا لا نريد تمثيل إشارة بل تعلّم مؤثّر يحلّ معادلة تفاضلية؟ وما حدود هذه الطرائق حين تُدفع إلى أقصاها؟ الفصل الأخير يجيب.

جدول الرموز (فهرس الفصل)

الرمز	المعنى
$H(z),\ A(z),\ B(z)$	دالة التحويل ومقاماها وبسطها
$h_k,\ b_k,\ a_k$	معاملات FIR والتلقيمين الأمامي والراجع
$d,\ K,\ R$	التوسيع وحجم النواة والحقل الاستقبالي
Q, K, V	استعلام/مفتاح/قيمة الانتباه
$A, \Delta, \bar{K}$	مصفوفة الحالة وخطوة التفريد ونواة SSM
$c,\ \phi_s$	شرط التوليد والتحليل الطيفي بمقياس s

نهاية الفصل الثالث والخمسين — ومنه نعبر إلى آفاق حديثة ومستقبلية في الفصل الرابع والخمسين والأخير.

آفاق حديثة: إشارة الرسوم، المؤثّرات العصبية، والتمثيلات الضمنية

الشعار: «حين تتغيّر شبكة العالم، يتغيّر معنى التردّد — ومن يعرف قاعدة القياس يعرف كيف يستمع.»

تمهيد قصصي للفصل: ما التردّد على شبكة؟

كلّ ما تعلّمته عن التردّد كان على **شبكة منتظمة**: خطٌّ للزمن، أو شبكةٌ للصورة. فماذا لو كانت إشاراتك على **رسم**؟ شبكة تواصل اجتماعي، أو جزيء، أو شبكة طرق، أو الدماغ؟ لا يوجد «زمن» ينزلق، ولا «مكان» متساوٍ؛ فهذا الرمز جاره ثلاثة، وذاك جاره مئة.

ومع ذلك نستطيع أن نتكلّم عن التردّد: نأخذ **لابلاسي الرسم** $L = D - A$، ونحلّل قيمه الذاتية، فتكون القيم الذاتية الصغيرة «تردّدات منخفضة» (إشارة ناعمة على الرسم) والكبيرة «تردّدات عالية» (إشارة متذبذبة بين الجيران). هذه هي بساطة الفكرة وعمقها — وهي التي تفتح الباب لأحد أحدث الفصول في الكتاب: **معالجة الإشارة على الرسوم، ثم المؤثّرات العصبية** التي لا تتعلّم دالة بل **مؤثّراً** يحلّ معادلة، ثم **التمثيلات الضمنية** التي تكتب الصورة دالةً لا مصفوفة، وأخيراً حدود كلّ ذلك وما بعده.

هذا الفصل خاتمة الجزء التاسع، وفيه ننظر إلى الأمام: إلى الضغط العصبي، وإلى الحوسبة الكمّية والتناظرية، وإلى الاستشعار الحدثي، وإلى ما لا نعرفه بعد.

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. تعريف **تحويل فورييه على رسم** وقراءة القيم الذاتية بوصفها تردّدات.

٢. بناء مرشّح طيفي على رسم وتقريبه الموضعي (ChebNet) وتفسير حدوده.

٣. صياغة **المؤثّر العصبي الفورييه (FNO)** وشرح حياده للدقة (resolution invariance).

٤. تفسير **التمثيلات الضمنية** (INR/SIREN) والتحيّز الطيفي وعلاجه.

٥. فهم **الضغط العصبي** ومفاضلة المعدّل والتشويه (rate–distortion).

٦. معرفة اتجاهات المستقبل: الكمّ، والتناظرية/النيورومورفيك، والاستشعار الحدثي.

٧. تركيب صورةٍ موحّدة: تحويلٌ خطّي يحفظ الطاقة + تعلّمٌ غير خطّي في فضاء أفضل.

المتطلبات المسبقة

الفصول 43 (الرسوم وGNN)، 51–53، والفصل 40 ،(NTK) والفصل 41 (النماذج التوليدية).

خريطة الفصل

القسم	القانون/النظرية	عدد الأمثلة المحلولة
1.54	الإشارة على رسم: المفردات	—
2.54	تحويل فورييه على الرسوم والمرشّحات الطيفية	15
3.54	المؤثّرات العصبية الفورييه (FNO)	15
4.54	التمثيلات الضمنية والانحياز الطيفي	15
5.54	الضغط العصبي ومفاضلة المعدّل والتشويه	15
6.54	معالجة الإشارة الكمّية (QSP/QFT)	15
7.54	الاستشعار الحدثي والإشارات النبضية	15
8.54	خريطة المستقبل وحدود النماذج	15
9.54	تمارين غنية + ملخص + خاتمة الجزء	30 تمريناً

المصطلحات الإنجليزية المقابلة

· Filtering Spectral · Spectrum Laplacian · Transform Fourier Graph · Processing Signal Graph Neural Implicit · Invariance Resolution · Operator Neural Fourier · Operator Neural · ChebNet Quantum · Rate–Distortion · Compression Neural · Bias Spectral · SIREN · Representation · Signals Spiking · Sensing Event-Based · Transform Fourier Quantum · Processing Signal Neuromorphic

رسمٌ $G = (V, E)$ بعدد عقد N ومصفوفة تجاور A؛ **وإشارة على الرسم** هي قيمة لكلّ عقدة: $x \in \mathbb{R}^N$. واللابلاسي:

$$L = D - A, \qquad \mathcal{L}(x) = \frac{1}{2}\sum_{(i,j)\in E}(x_i - x_j)^2 = x^\top L x \tag{1.1.54}$$

$$L = U\Lambda U^\top, \quad \lambda_1 \le \cdots \le \lambda_N, \qquad \hat{x}_k = \langle x, u_k\rangle \text{ (تحويل فورييه الرسومي)} \tag{2.1.54}$$

الرمز	المعنى	ملاحظة
L	لابلاسي الرسم	موجب شبه محدّد
λ_k, u_k	القيم والمتجهات الذاتية	التردّد والقاعدة
$\hat{x}_k$	المعامل الطيفي الرسومي	نظير c_k
$\mathcal{L}(x)$	«النعومة» (Dirichlet energy)	صغيرة ⇒ إشارة ناعمة
$g(\lambda)$	استجابة المرشّح الطيفي	تُعلَّم أو تُصمَّم

القاعدة الذهبية: λ صغير ⇒ مكوّن ناعم على الرسم (يختلف قليلاً بين الجيران)؛ وλ كبير ⇒ مكوّن متذبذب (يتغيّر بحدّة).

تمهيد استفهامي

شبكةٌ اجتماعية تنتشر فيها شائعة. كيف «نرشّح» هذه الإشارة؟ في الزمن نقطع الترددات العالية؛ فما التردّد العالي هنا؟ الجواب: أن تختلف الشائعة بين صديقين متجاورين اختلافاً حادّاً. فالنعومة على الرسم هي «التردّد المنخفض»، والاضطراب بين الجيران هو «التردّد العالي».

وهكذا يولد تحليلٌ طيفي كامل على الرسوم: تحويل، وترشيح، وموجات رسومية، وأطياف قدرة. لكن ثمّة فارقٌ جوهري عن الزمن: **الطيف يعتمد على الرسم نفسه.** فمرشّحٌ تعلّمته على رسمٍ لا يصلح لآخر ذي طيف مختلف — وهذا أحد أهمّ حدود GNN الطيفية (الفصل 43)، وهو ما يدفع البحث إلى مرشّحات موضعية أو «نقل طيفي».

صياغة رسمية

$$\text{GFT: } \hat{x} = U^{\top} x, \qquad x = U \hat{x} \tag{1.2.54}$$

$$\text{مرشّح طيفي: } y = U\, g(\Lambda)\, U^{\top} x, \qquad g(\Lambda) = \operatorname{diag}(g(\lambda_1), \dots, g(\lambda_N)) \tag{2.2.54}$$

$$\text{تقريب كثير حدود (ChebNet): } g(\lambda) \approx \sum_{k=0}^{K} \theta_k T_k(\tilde{\lambda}) \Rightarrow y \approx \sum_{k} \theta_k T_k(\tilde{L}) x \tag{3.2.54}$$

$$\text{الطاقة الطيفية: } \|x\|^2 = \sum_k |\hat{x}_k|^2, \qquad \mathcal{L}(x) = \sum_k \lambda_k |\hat{x}_k|^2 \tag{4.2.54}$$

جدول الرموز

الرمز	المعنى	ملاحظة
U	قاعدة القيم الذاتية للابلاسي	«قاعدة فوريه» الرسم
$g(\cdot)$	استجابة المرشّح الطيفي	تحدّد سلوك GNN
T_k	متعدّدات تشيبيشف	تقريب موضعي برتبة k
$\tilde{L}$	لابلاسي معاير	$\frac{2}{\lambda_{\max}} L - I$
K	رتبة كثير الحدود	حجم «المجال» الموضعي

برهان (مخطط)

١. **(1.2.54)** L متماثل $\Rightarrow$ له تحليلٌ طيفي متعامد $\Rightarrow U$ قاعدة كاملة.

٢. **(2.2.54)** المرشّح يُعرَّف بضرب كلّ معامل بـ$g(\lambda_k)$ $\Rightarrow$ نظير الترشيح في فوريه.

٣. **(3.2.54)** متعدّدات تشيبيشف تعطي تقريباً بكثير حدود من رتبة K $\Rightarrow$ تنفيذه موضعي (جيران حتى K قفزة) بلا حساب القاعدة الذاتية ($O(N^3)$).

٤. **(4.2.54)** بارسيفال على الرسم؛ وصيغة الطاقة من تعريف $x^{\top} L x$. ■

شروط الصحّة: القاعدة تعتمد على الرسم $\Rightarrow$ المرشّحات المتعلَّمة في الطيف **لا تُنقل** بين الرسوم ذات الأحجام/الأطياف المختلفة (ضعف التعميم). واللابلاسي المُعايَر ($\hat{A}_{\text{sym}}$) هو المستخدم عملياً في GCN.

أمثلة محلولة (15)

تحويل فوريه على الرسم: قاعدة القيم الذاتية للابلاسي
Graph Fourier Transform via Laplacian eigenbasis



التردّد على الرسم = قيمة ذاتية للابلاسي: صغيرة ⇒ ناعم على الرسم، كبيرة ⇒ متذبذ
الترشيح الطيفي: y=U g(\lambda)U^\top x — وChebNet يقرّبه بكثير حدود مود
حدوده: الاعتماد على طيف الرسم ⇒ ضعف النقل بين الرسوم (الفصل 43).

شكل ١٠٥٤: *
تحويل فوريه على الرسم عبر القاعدة الذاتية للابلاسي والترشيح الطيفي

مثال (1-2.54): طيف رسم بسيط

المعطيات: مسار من 4 عقد. الحل: الخطوة 1: قيم L الذاتية $0, 0.586, 2, 3.414 \Rightarrow$ «تردّدات» الرسم. النتيجة: الطيف يحمل شكل الرسم. الربط بالذكاء الاصطناعي: طيف لابلاسي يُستخدم بصمةً للرسوم.

مثال (2-2.54): إشارة ناعمة على رسم

المعطيات: x ثابتة على كلّ العقد. الحل: الخطوة 1: $\mathcal{L}(x) = 0 \Rightarrow$ كلّ الطاقة عند $\lambda_1 = 0$. النتيجة: الثبات = تردّد صفري. الربط بالذكاء الاصطناعي: نظيرُ المكوّن المستمر DC في الصور.

مثال (3-2.54): إشارة متذبذبة

المعطيات: $x_i = (-1)^i$ على مسار. الحل: الخطوة 1: الطاقة كلها عند أكبر قيمة ذاتية $\Rightarrow$ تردّد عالٍ. النتيجة: التذبذب بين الجيران = تردّد عالٍ. الربط بالذكاء الاصطناعي: هذا سببُ «oversmoothing» في GNN العميقة.

مثال (4-2.54): GCN مرشّحاً طيفياً

المعطيات: $y = \hat{A}_{\text{sym}} x W$. الحل: الخطوة 1: يعادل مرشّحاً $g(\lambda) = 1 - \lambda$ تقريباً $\Rightarrow$ تمرير منخفض. النتيجة: GCN يلطّف الإشارة على الرسم. الربط بالذكاء الاصطناعي: يفسّر ظاهرة الإفراط في التنعيم (oversmoothing).

مثال (2.54-5): ChebNet موضعي

المعطيات: $K = 3$. الحل: الخطوة 1: المرشّح يعتمد على جيران حتى 3 قفزات $\Rightarrow$ موضعي وقابل للنقل بين الرسوم. النتيجة: نقلٌ أفضل من المرشّح الطيفي الكامل. الربط بالذكاء الاصطناعي: الموضعية مفتاح التعميم في GNN.

مثال (2.54-6): حساب التكلفة

المعطيات: رسم بـ10^5 عقدة. الحل: الخطوة 1: التحليل الذاتي $O(N^3)$ مستحيل $\Rightarrow$ نستخدم كثيرات حدود $O(|E|K)$. النتيجة: الموضعية مطلبٌ حسابي لا نظري فقط. الربط بالذكاء الاصطناعي: قابلية التوسّع تحكم المعماريات.

مثال (2.54-7): مويجات رسومية

المعطيات: نريد تحليلاً متعدد المقاييس على رسم. الحل: الخطوة 1: نبني مرشّحات نطاق على فترات من الطيف $\Rightarrow$ «مويجات» رسومية. النتيجة: تمثيلٌ متعدد المقاييس على بنية غير منتظمة. الربط بالذكاء الاصطناعي: يربط الفصل 52 بالرسوم.

مثال (2.54-8): تجميع (pooling) طيفي

المعطيات: نريد تصغير الرسم. الحل: الخطوة 1: نحتفظ بالمكوّنات منخفضة التردّد $\Rightarrow$ تجميع يحفظ البنية الكبيرة. النتيجة: تجميعٌ مبرّر طيفيّاً. الربط بالذكاء الاصطناعي: pooling Graph الطيفي (Graclus/NDP).

مثال (2.54-9): التردّد العالي في الرسوم والضجيج

المعطيات: تسميات عقد مشوّشة. الحل: الخطوة 1: الضجيج يظهر عالي التردّد $\Rightarrow$ ترشيح منخفض يحسّن التصنيف. النتيجة: ترشيحٌ كتنظيف. الربط بالذكاء الاصطناعي: التنعيم على الرسم يحسّن الأداء عند ضجيج التسميات.

مثال (2.54-10): حدود النقل الطيفي

المعطيات: مرشّح تعلّم على رسم A وطُبّق على B. الحل: الخطوة 1: أطياف مختلفة $\Rightarrow$ المرشّح «خارج النطاق» $\Rightarrow$ تدهور. النتيجة: ضعفُ النقل الطيفي. الربط بالذكاء الاصطناعي: مبرّرُ GNN الموضعية/الهيكلية.

مثال (2.54-11): طيف مجتمعي

المعطيات: رسم بمجتمعين. الحل: الخطوة 1: المتجه الذاتي الثاني (Fiedler) يفصل المجتمعين $\Rightarrow$ أدنى تردّد غير صفري. النتيجة: كشفُ المجتمعات مسألةٌ طيفية. الربط بالذكاء الاصطناعي: التقطيع الطيفي (spectral

clustering).

مثال (12-2.54): حيوية الرسم بالطيف

المعطيات: مقارنة رسومين. الحل: الخطوة 1: نحسب «طاقة» الطيف ⇒ مقياس الروابط وانتظامها. النتيجة: واصفاتٌ طيفية للرسوم. الربط بالذكاء الاصطناعي: مميّزات الرسوم دون تعلّم.

مثال (13-2.54): GNN الطيفية في الكيمياء

المعطيات: جزيء (رسم ذرات). الحل: الخطوة 1: التمثيل الطيفي يحترم تناظرات الجزيء ⇒ تنبؤ أفضل بالخصائص. النتيجة: نجاح GNN في الكيمياء الحسابية. الربط بالذكاء الاصطناعي: اكتشاف الأدوية وتعلّم الجزيئات.

مثال (14-2.54): الرسم بوصفه تعميماً للشبكة

المعطيات: شبكة صور منتظمة. الحل: الخطوة 1: لابلاسي الشبكة ⇒ قاعدته = جيوب فوريه (DCT) ⇒ فوريه حالة خاصّة. النتيجة: التعميم يحيط بالكلاسيكي. الربط بالذكاء الاصطناعي: وحدةُ المفاهيم عبر الفصول.

مثال (15-2.54): إشارة الزمن رسمٌ أيضاً

المعطيات: سلسلة زمنية. الحل: الخطوة 1: رسم مسار ⇒ لابلاسي ⇒ طيف يقابل DCT ⇒ تحليل زمني ممكن بالأدوات نفسها. النتيجة: منظورٌ موحّد. الربط بالذكاء الاصطناعي: تعلّمُ الرسوم للسلاسل الزمنية اتجاهٌ حديث.

أخطاء شائعة

١. **توقّع نقل المرشّح الطيفي بين الرسوم:** الطيف خاصّ بالرسم.

٢. **حساب التحليل الذاتي لرسوم كبيرة:** مستحيل حسابيّاً ⇒ كثيرات حدود.

٣. **الخلط بين «التردّد» والقيمة الذاتية:** العلاقة طردية (كبير ⇒ عالٍ).

٤. **تجاهل oversmoothing:** GCN المتكرّرة تقتل الإشارة.

٥. **استخدام مرشّح عالي الرتبة بلا حاجة:** يوسّع المجال بلا مبرّر.

تمهيد استفهامي

الشبكات العادية تتعلّم **دالة**: من نقطة إلى قيمة. لكن كثيراً من مسائل العلم تتطلّب تعلّم **مؤثّر** (operator): من **دالة إلى دالة** — من حقل سرعة ابتدائي إلى حله بعد ثانية، أو من معاملات معادلة تفاضلية إلى حلّها. شبكةٌ عادية لا تفعل ذلك بسهولة: فهي مرتبطة بدقة الشبكة التي تدربت عليها.

المؤثّر العصبي الفوريه (FNO) يحلّ المشكلة بضربةٍ طيفية: طبقةٌ تحوّل الحقل إلى مجال فوريه، وتضرب الأوضاع المنخفضة بمصفوفة متعلَّمة، وتعيد بالتحويل العكسي؛ ثم تُضاف لاخطّية موضعية. والنتيجة مذهلة: **حيادٌ للدقة** (resolution invariance) — النموذج المدرب على شبكة 64×64 يعمل على 256×256 بلا إعادة تدريب، لأنّه تعلّم في فضاء الدوال لا في فضاء البكسلات.

صياغة رسمية

$$v_{t+1}(x) = \sigma\Big(W v_t(x) + \mathcal{F}^{-1}\big(R_k \cdot (\mathcal{F} v_t)_k\big)(x)\Big) \tag{1.3.54}$$

$$|k| \le K \ \Rightarrow \ \text{التكلفة } O(N \log N) \text{ لا } O(N^2) \text{ فقط} \qquad \text{(2.3.54)}$$ الاقتطاع: نحتفظ بـ

$$\text{في فضاء الدوالِّ لا يعتمد على شبكة العيّنات } R_k \text{ حياد الدقة: الأوزان} \tag{3.3.54}$$

$$\|\mathcal{G} - \mathcal{G}_\theta\| \le \underbrace{\varepsilon_{\text{اقتطاع}}}_{\text{ذيل الطيف}} + \underbrace{\varepsilon_{\text{تقريب}}}_{\text{سعة الشبكة}} + \varepsilon_{\text{تحسين}} \tag{4.3.54}$$ الخطأ:

جدول الرموز

الرمز	المعنى	ملاحظة
v_t	الحقل في الطبقة t	دالة لا متجه
R_k	مصفوفة الأوزان للوضع k	متعلَّمة
K	عدد الأوضاع المحفوظة	ميزانية التردّد
$\mathcal{G}$	المؤثّر الهدف	يحلّ معادلة
ε	مكوّنات الخطأ	كلٌّ له علاج

برهان (مخطط)

١. **(1.3.54)** دمجُ مسارٍ خطّي موضعي (Wv) مع مسارٍ طيفي عالمي (ضرب في مجال فوريه) ثم لاخطّية.

٢. **(2.3.54)** الاقتطاع عند K يجعل الأوزان $K \times d \times d$ لا $N \times N \Rightarrow$ تكلفة لوغاريتمية عبر FFT.

٣. **(3.3.54)** التحويل يعمل على أوضاع «مسمّاة» بالتردّد، فالنموذج لا يرى حجم الشبكة $\Rightarrow$ حياد الدقة.

٤. **(4.3.54)** تحليلٌ قياسي لخطأ التقريب: ثلاثة مصادر تُعالج بزيادة K والسعة والتحسين. ■

شروط الصحّة: الحياد للدقة تقريبي (يتطلّب أن تكون المدخلات ممثَّلة بدقة على الشبكة الجديدة). والاقتطاع الشديد يفقد التفاصيل (ويعيدنا إلى آثار غيبس 4.50)؛ لذا تُدمج مسارات موضعية.

أمثلة محلولة (15)

طبقة في مجال التردّد :(FNO) المؤثّر العصبي الفوريه
Fourier Neural Operator layer



الاقتطاع عند $k \le K$ يجعل التعقيد $O(N \log N)$ ويمنح حياداً للدقة (tion-invariant)
يحلّ معادلات تفاضلية جزئية أسرع بأضعاف من الشبكات المكانية.

شكل ٢.٥٤: *
طبقة المؤثر العصبي الفوريه: تحويل فضرب للأوضاع المحفوظة ثم تحويل عكسي

مثال (3.54-1): تدريب على دقة والتطبيق على أخرى

المعطيات: تدريب على 64^2 وتطبيق على 256^2. الحل: الخطوة 1: الأوزان في فضاء الأوضاع $\Rightarrow$ تطبَّق على أيّ شبكة تحمل الأوضاع نفسها. النتيجة: حيادٌ عملي للدقة. الربط بالذكاء الاصطناعي: ميزةٌ مستحيلة في CNN العادية.

مثال (3.54-2): اختيار K

المعطيات: حلول ناعمة (معادلة حرارة). الحل: الخطوة 1: الطيف يموت سريعاً $\Rightarrow 12 \quad = \quad K$ يكفي. النتيجة: كفاءة عالية. الربط بالذكاء الاصطناعي: K يُقرأ من ذيل طيف الحلول (8.50).

مثال (3.54-3): حلول متقطّعة

المعطيات: موجات صدمية. الحل: الخطوة 1: ذيلٌ بطيء $\Rightarrow$ الاقتطاع يفقد الحدة $\Rightarrow$ نحتاج K كبير أو مساراً موضعيّاً. النتيجة: حدود FNO عند الانقطاعات. الربط بالذكاء الاصطناعي: مفاضلة الطيف مقابل الموضعية (كما في المويجات).

مثال (3.54-4): تسريع مقابل المحاكاة

المعطيات: محاكاة CFD تستغرق ساعات. الحل: الخطوة 1: FNO يعطي الحلّ في ثوانٍ بعد التدريب $\Rightarrow$ تسريع بأضعاف. النتيجة: تغييرٌ في اقتصاديات المحاكاة العلمية. الربط بالذكاء الاصطناعي: «AI for Science» أحد أكبر الاتجاهات.

مثال (5-3.54): التكلفة مقابل CNN

المعطيات: شبكة 256^2. الحل: الخطوة 1: CNN: عشرات الطبقات $\Rightarrow$ مئات الملايين من العمليات؛ FNO: FFT لكلّ طبقة $\Rightarrow$ أقلّ. النتيجة: كفاءة للاتصال العالمي. الربط بالذكاء الاصطناعي: الاتصال العالمي رخيص في مجال التردّد (5.53).

مثال (6-3.54): أثر الاقتطاع على الحلّ

المعطيات: K صغير جدّاً. الحل: الخطوة 1: الحلّ ناعم أكثر من اللازم $\Rightarrow$ فقدان الفيزياء الدقيقة. النتيجة: ميزانيةُ K قرارُ فيزياء. الربط بالذكاء الاصطناعي: اختيارُ السعة مرتبط ببنية المسألة.

مثال (7-3.54): FNO على رسم

المعطيات: هندسة غير منتظمة. الحل: الخطوة 1: FFT يتطلّب شبكة منتظمة $\Rightarrow$ نستخدم GNO أو إسقاطاً على شبكة. النتيجة: القيدُ يعيدنا إلى 2.54. الربط بالذكاء الاصطناعي: لا أداة عالمية لكلّ الهندسات.

مثال (8-3.54): التعلّم من البيانات مقابل الفيزياء

المعطيات: بيانات قليلة ومعادلة معلومة. الحل: الخطوة 1: نضيف فقداناً للمعادلة (physics-informed) $\Rightarrow$ تعميم أفضل. النتيجة: دمجُ المعرفة المسبقة مفيد. الربط بالذكاء الاصطناعي: PINNs اتجاهٌ موازٍ.

مثال (9-3.54): التهيئة الطيفية

المعطيات: بدء R_k بصفر أو بصغر. الحل: الخطوة 1: البدء صغيراً يجعل النموذج قريباً من الهوية $\Rightarrow$ تدريب مستقر. النتيجة: التهيئة تحمي من الانفجار الطيفي. الربط بالذكاء الاصطناعي: نظيرُه التهيئة في ResNet.

مثال (10-3.54): التعميم خارج التوزيع

المعطيات: معاملات معادلة خارج نطاق التدريب. الحل: الخطوة 1: FNO قد يفشل $\Rightarrow$ تعميم المؤثّرات يحتاج تنوّعاً في التدريب. النتيجة: حدودٌ معلومة. الربط بالذكاء الاصطناعي: OOD مشكلة عامة (15-8.53).

مثال (11-3.54): خطأ الاقتطاع كمّياً

المعطيات: طيف الحلول $k^{-3} \sim$ و$K = 20$. الحل: الخطوة 1: الطاقة المتبقية $\Rightarrow \sim \int_{20}^{\infty} k^{-6} dk \approx 2 \times 10^{-7}$ ضئيلة. النتيجة: حسابُ الميزانية من الطيف. الربط بالذكاء الاصطناعي: يربط (4.5.50) بـFNO.

مثال (3.54-12): مزجٌ طيفي في المحوّلات أيضاً

المعطيات: FNet كان المزيج ذاته (4.8.51). الحل: الخطوة 1: الفكرة واحدة: مزج عالمي رخيص في مجال التردّد. النتيجة: وحدةٌ عبر المعماريات. الربط بالذكاء الاصطناعي: الأفكار الطيفية تتكرّر في كلّ مكان.

مثال (3.54-13): التطبيقات الصناعية

المعطيات: نمذجة تدفّق حول جناح. الحل: الخطوة 1: FNO يتعلّم خريطة الشكل⇒الحقل ⇒ دراسة تصميمات كثيرة بسرعة. النتيجة: تسريعُ دورات التصميم الهندسي. الربط بالذكاء الاصطناعي: أثرٌ اقتصادي مباشر.

مثال (3.54-14): دقة التنبؤ مقابل التكلفة

المعطيات: محاكاة دقيقة جدّاً مقابل FNO سريع. الحل: الخطوة 1: الاستخدام الأمثل: FNO للاستكشاف والمحاكاة الدقيقة للتحقّق النهائي. النتيجة: تكاملٌ لا استبدال. الربط بالذكاء الاصطناعي: النماذج السريعة تُكمّل المحاكاة ولا تلغيها.

مثال (3.54-15): ما بعد FNO

المعطيات: مؤثّرات على هندسات عامة. الحل: الخطوة 1: DeepONet (فروع/جذع) وGNO ورقع مويجية ⇒ اتجاهات مفتوحة. النتيجة: المجال يتطوّر سريعاً. الربط بالذكاء الاصطناعي: بحثٌ نشط في تعلّم المؤثّرات.

أخطاء شائعة

١. **توقّع حياد دقة تام:** تقريبي ويتطلّب تمثيلاً جيداً.

٢. **اقتطاع K بلا حساب ذيل الطيف:** فقدان الفيزياء.

٣. **استخدام FFT على هندسة غير منتظمة:** يحتاج معالجة.

٤. **تجاهل أن الحلول المتقطّعة تحتاج مساراً موضعيّاً:** الطيف وحده لا يكفي.

٥. **الخلط بين تعلّم الدالة وتعلّم المؤثّر:** مختلفان جوهريّاً.

تمهيد استفهامي

هل يمكن أن تكون الصورة «دالة» لا مصفوفة؟ نعم: شبكةٌ تأخذ إحداثيّاً (x, y) وتعطي اللون — هذا هو **التمثيل الضمني العصبي** (INR). صورةٌ واحدة تصير أوزانَ شبكة؛ ومشهدٌ ثلاثي الأبعاد يصير دالة كثافة وحقل لون (NeRF).

لكنّ الشبكات العادية (MLP) بـReLU تعجز عن التفاصيل الدقيقة: فهي متحيّزة للترددات المنخفضة (8.51). والحلّ جاء من زاويتين: **تفعيلٌ دوري** (SIREN بـsin) يمنح الشبكة طيفاً غنيّاً منذ البداية، **وميزات فوريه عشوائية**

تُدخل الترددات صراحةً في المدخلات. وكلاهما يعيدنا إلى الدرس نفسه: **أعطِ النموذج القاعدة المناسبة فيفضّ ترددّاته بنفسه.**

صياغة رسمية

$$\text{INR: } f_\theta(x,y) \to (R,G,B), \qquad \min_\theta \sum_p \|f_\theta(p) - I(p)\|^2 \tag{1.4.54}$$

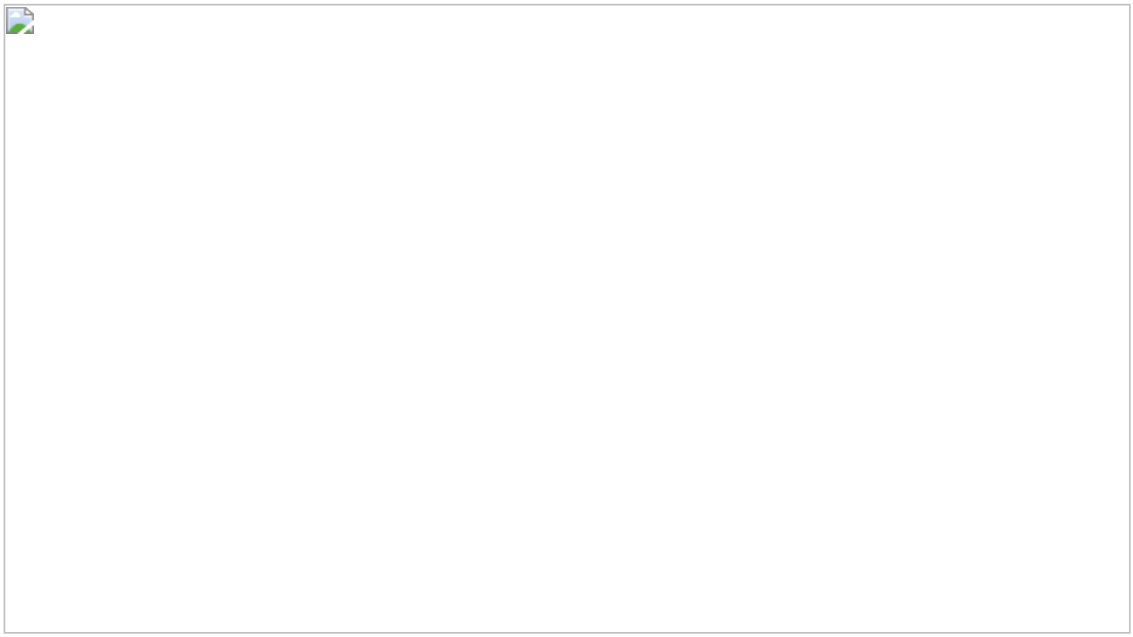
$$\text{SIREN: } z_1 = \sin(\omega_0 W_0 x + b_0), \quad z_\ell = \sin(W_\ell z_{\ell-1} + b_\ell) \tag{2.4.54}$$

$$\text{ميزات فوريه: } \gamma(x) = \big[\cos(2\pi B x),\ \sin(2\pi B x)\big], \quad B \sim \mathcal{N}(0, \sigma^2) \tag{3.4.54}$$

$$\text{NTK: التحيّز الطيفي عبر } |\hat{f}_t(k) - \hat{f}^\star(k)| \sim e^{-\lambda_k t}, \qquad \lambda_k \searrow \text{ مع } |k| \tag{4.4.54}$$

جدول الرموز

الرمز	المعنى	ملاحظة
f_θ	الشبكة بوصفها دالة	تمثيل ضمني
ω_0	تردّد التفعيل الأولي	يضبط الطيف (SIREN)
B	ترددات الترميز	عرض نطاق الميزات
λ_k	طيف NTK	يفسّر ترتيب التعلّم
NeRF	حقل إشعاعي عصبي	أشهر تطبيقات INR



شكل ٣.٥٤: *
التمثيلات الضمنية والتحيز الطيفي ودور SIREN وميزات فوريه

برهان (مخطط)

١. **(1.4.54)** الشبكة دالةٌ مستمرة على الإحداثي ⇒ تمثيلٌ بدقة غير محدّدة.

٢. **(2.4.54)** التفعيل الدوري يجعل مشتقات الشبكة محدّدة جيّداً ⇒ يمكن تمثيل التفاصيل الدقيقة (بخلاف ReLU التي مشتقاتها قطعية).

٣. **(3.4.54)** من نظرية بوخنر: النواة الثابتة ⇔ طيف الترددات ⇒ الترميز يجعل الشبكة «ترى» ترددات متعدّدة.

٤. **(4.4.54)** من ديناميكية NTK (الفصل 40 و1.8.51): المكوّن منخفض التردّد يتقارب أسرع. ■

شروط الصحّة: SIREN بتردّد عالٍ قد يتذبذب خارج منطقة التدريب (ضعف التعميم)؛ واختيار σ في الترميز مفاضلة تحيّز/تباين. والتدريب على INR أبطأ من تدريب CNN على الصور نفسها.

أمثلة محلولة (15)

مثال (4.54-1): صورة بشبكة

المعطيات: صورة 256^2 وMLP صغير. الحل: الخطوة 1: ندرّب الشبكة على كلّ بكسل ⇒ نحصل ضغطاً «ضمنياً». النتيجة: تمثيلٌ بدقة مستمرة. الربط بالذكاء الاصطناعي: ضغطٌ بمعاملات الشبكة (5.54).

مثال (4.54-2): لماذا ReLU تفشل في التفاصيل

المعطيات: MLP بـReLU تقرّب صورة حادّة. الحل: الخطوة 1: التحيّز الطيفي ⇒ تتعلّم النسخة الناعمة أولاً وببطء شديد للتفاصيل. النتيجة: صورة ضبابية. الربط بالذكاء الاصطناعي: يفسّر الحاجة إلى ترميز موضعي.

مثال (4.54-3): SIREN تحلّ المشكلة

المعطيات: نفس الشبكة بتفعيل جيبي. الحل: الخطوة 1: طيفٌ غنيّ ⇒ تمثيل التفاصيل والمشتقات بدقة. النتيجة: صورة حادّة ومشتقات صالحة. الربط بالذكاء الاصطناعي: مفيدٌ حيث المشتقات مهمة (فيزياء/هندسة عكسية).

مثال (4.54-4): ترميز فوريه في NeRF

المعطيات: إحداثي ثلاثي الأبعاد. الحل: الخطوة 1: نرمّزه بترددات هندسية ⇒ الشبكة تمثّل التفاصيل الدقيقة للمشهد. النتيجة: جودة NeRF الكلاسيكية مرتبطة بهذا الترميز. الربط بالذكاء الاصطناعي: مبرّرُ «positional encoding» في الرؤية الحاسوبية.

مثال (4.54-5): اختيار σ للترميز

المعطيات: σ صغير. الحل: الخطوة 1: نطاق ترددي ضيّق ⇒ نعومة مفرطة؛ وكبير ⇒ تذبذب وضجيج. النتيجة: معلومةٌ فائقة حسّاسة. الربط بالذكاء الاصطناعي: ضبطُها بالتحقق أو بالتحليل الطيفي.

مثال (4.54-6): التحيّز الطيفي مفيد أحياناً

المعطيات: بيانات مشوّشة. الحل: الخطوة 1: النموذج يتعلّم النسخة الناعمة أولاً ⇒ «ينظّف» قبل أن يحفظ الضجيج. النتيجة: تنظيمٌ ضمني. الربط بالذكاء الاصطناعي: يفسّر نجاح التوقّف المبكر (7-8.51).

مثال (4.54-7): دقة فائقة (super-resolution)

المعطيات: INR مدربة على صورة. الحل: الخطوة 1: نستعلم الشبكة عند إحداثيات أدق ⇒ دقة أعلى بلا تدريب جديد. النتيجة: تمثيلٌ مستمر ميزةٌ حقيقية. الربط بالذكاء الاصطناعي: مبرّرُ INR في الرسوم الطبية والرسوم المتجهة.

مثال (4.54-8): قياس الطيف المتعلَّم

المعطيات: نحلّل طيف الشبكة. الحل: الخطوة 1: نحسب استجابتها لتردّدات مختلفة ⇒ نرى ترتيب التعلّم. النتيجة: أداةُ تشخيص قابلة للقياس. الربط بالذكاء الاصطناعي: تحليل NTK عملياً (الفصل 40).

مثال (4.54-9): التمثيل الضمني كضغط

المعطيات: فيديو بدقة عالية. الحل: الخطوة 1: شبكة تمثّله ⇒ معاملات أقلّ من البكسلات عند ضغط عالٍ. النتيجة: ضغطٌ عصبي (5.54). الربط بالذكاء الاصطناعي: «NeRV» ومقاييس الضغط العصبي.

مثال (4.54-10): أثر التهيئة

المعطيات: SIREN بتهيئة عشوائية كبيرة. الحل: الخطوة 1: تذبذب عنيف ⇒ تدريب غير مستقر ⇒ تهيئة مخصّصة مطلوبة. النتيجة: تفصيلٌ حاسم في SIREN. الربط بالذكاء الاصطناعي: التهيئة المخصّصة بالتفعيل قاعدة عامة.

مثال (4.54-11): التمثيل الضمني في الهندسة العكسية

المعطيات: قياسات قليلة من مجال فيزيائي. الحل: الخطوة 1: INR بمشتقات صحيحة ⇒ حلّ معادلة بفقدانٍ فيزيائي. النتيجة: تطبيقات علمية واسعة. الربط بالذكاء الاصطناعي: يربط 3.54 بـ4.54.

مثال (4.54-12): حدود التعميم الموضعي

المعطيات: استعلام خارج منطقة التدريب. الحل: الخطوة 1: التمثيل الضمني يتصرف بلا ضمان ⇒ قد يهلوس. النتيجة: حدود INR. الربط بالذكاء الاصطناعي: التعميم خارج التوزيع مشكلة عامة.

مثال (13-4.54): سرعة التدريب

المعطيات: صورة كبيرة بـINR. الحل: الخطوة 1: كلّ بكسل عيّنة تدريب ⇒ آلاف التكرارات ⇒ أبطأ من CNN. النتيجة: مفاضلة الجودة مقابل الوقت. الربط بالذكاء الاصطناعي: التطبيقات الآنية تفضّل CNN.

مثال (14-4.54): هجائن حديثة

المعطيات: نريد سرعة CNN ومرونة INR. الحل: الخطوة 1: شبكات بميزات متعلَّمة + استعلام مستمر (مثل LIIF) ⇒ أفضل الأمرين. النتيجة: اتجاهٌ معاصر. الربط بالذكاء الاصطناعي: الهجائن تسود في التطبيق العملي.

مثال (15-4.54): العلاقة بالمويجات

المعطيات: قارن الترميز الجيبي بالمويجي. الحل: الخطوة 1: الجيبي عالمي والمويجي موضعي ⇒ المويجي أفضل للإشارات المتقطّعة (52). النتيجة: اختيارُ الترميز بحسب بنية الإشارة. الربط بالذكاء الاصطناعي: بحثٌ مفتوح في ترميزاتٍ هجينة.

أخطاء شائعة

١. **توقّع أن MLP بـReLU يمثّل التفاصيل:** تحيّز طيفي قوي.

٢. σ **ترميز بلا ضبط:** إما ضباب أو ضجيج.

٣. **تجاهل تهيئة SIREN المخصّصة:** عدم استقرار.

٤. **الظنّ أن INR أسرع من CNN:** أبطأ تدريباً عادةً.

٥. **استعلام خارج منطقة التدريب بلا حذر:** هلوسة محتملة.

تمهيد استفهامي

الضغط الكلاسيكي (JPEG وMP3 وH.264) مبنيّ على تحويلاتٍ ثابتة (DCT، مويجات) وتكميمٍ مصمّم باليد، وعلى ترميز إنتروبي في النهاية. كلّ خطوةٍ مفهومة، لكنّ كلّ خطوةٍ أيضاً **مثبّتة**: لا تتكيّف مع محتوانا.

الضغط العصبي يفكّ هذا التثبيت: مُرمِّزٌ يتعلّم التحويل، وتكميمٌ يُدرَّب (بتمرير تدرّج عبر تكميمٍ مُلطَّف)، ونموذجٌ إنتروبي يتعلّم توزيع الرموز. الخسارة واحدة: $D + \lambda R$ — تشويهٌ مقابل معدّل بِتّات. وهنا تعود نظرية المعلومات (الجزء الخامس) لتكون **اللغة التي تُكتب بها خسارة الضغط**: فمعدّل البِتّات ليس إلا إنتروبيا الترميز، والتشويه يقاس بمعيارٍ إدراكي.

صياغة رسمية

$$\min_{\theta,\phi} \mathbb{E}\big[d(x,\hat{x})\big] + \lambda\,\mathbb{E}\big[-\log_2 p_{\hat{y}}(\hat{y})\big] \tag{1.5.54}$$

$$\hat{y} = Q\big(E_\theta(x)\big), \qquad \hat{x} = D_\phi(\hat{y}), \qquad R = \mathbb{E}[-\log_2 p_{\hat{y}}], \quad D = \mathbb{E}\, d(x, \hat{x}) \tag{2.5.54}$$

$$R \geq H(\hat{y}) \geq I(x; \hat{y}) \tag{3.5.54}$$ والمساواة بترميز مثالي حدّ معلوماتي:

$$\lambda = -\frac{dR}{dD} \tag{4.5.54}$$ محدّب متناقص، و$R(D)$ منحنى المعدّل-التشويه:

جدول الرموز

الرمز	المعنى	ملاحظة
E_θ, D_ϕ	المُرمِّز والمُفكِّك	شبكتان
Q	التكميم	فقدانٌ محسوب ومصدر الصعوبة
$p_{\hat{y}}$	نموذج الإنتروبيا	يحدّد معدّل البِتّات
R, D	المعدّل والتشويه	مفاضلة واحدة
λ	معامل المفاضلة	ميل المنحنى

الضغط العصبي: من الترميز اليدوي إلى التعلّم

Learned compression pipeline



الخسارة: D + \lambda R — مفاضلة التشويه مقابل معدّل البِتّات (e–distortion:

الربط بنظرية المعلومات (الجزء الخامس): معدّل البِتّات ≈ الإنتروبيا المرمّزة.

شكل ٤.٥٤: *

خطوة الضغط العصبي: مُرمِّز عصبي ثم تكميم ثم ترميز إنتروبي

برهان (مخطط)

١. **(1.5.54)** صياغة لاجرانجيّة لمسألة «أقلّ تشويه بمعدّل محدّد» (أو العكس).

٢. **(3.5.54)** من نظرية الترميز المصدر (الفصل 28): معدّل البِتّات $\geq$ الإنتروبيا $\geq$ المعلومات المتبادلة.

٣. **(4.5.54)** منحنى $R(D)$ نتيجة تحسين مقيد؛ وλ ميلُه $\Rightarrow$ كلّ λ يعطي نقطةً على المنحنى.

٤. **(التكميم)** غير قابل للتفاضل ⇒ نستخدم تكميمًا مُلطّفاً (إضافة ضجيج موحّد أو تمرير مستقيم). ■

شروط الصحّة: المقاييس الإدراكية (SSIM/LPIPS) قد تتعارض مع MSE؛ فالضغط «الأفضل» بالمقياس قد يكون أسوأ إدراكيًّا. والتعقيد الحسابي للمُرمِّزات العصبية أعلى بكثير من الكلاسيكية.

أمثلة محلولة (15)

مثال (5.54-1): تفسير الخسارة

المعطيات: λ كبير. الحل: الخطوة 1: العقاب على البِتّات أشدّ ⇒ ضغط أعلى وتشويه أكثر. النتيجة: λ يختار نقطة العمل. الربط بالذكاء الاصطناعي: نظيرُه تنظيم L2 في التعلّم (الفصل 22).

مثال (5.54-2): دور نموذج الإنتروبيا

المعطيات: رمزان أحدهما نادر. الحل: الخطوة 1: الإنتروبيا تكافئ النادر ببِتّات أكثر ⇒ الترميز يتكيّف. النتيجة: الضغط يقترب من الحدّ المعلوماتي. الربط بالذكاء الاصطناعي: صلةٌ مباشرة بالفصل 28.

مثال (5.54-3): التكميم والتدرّج

المعطيات: تكميمٌ صلب. الحل: الخطوة 1: مشتقته صفر ⇒ نستخدم ضجيجاً موحّداً أثناء التدريب (أو straight-through). النتيجة: تدريبٌ ممكن. الربط بالذكاء الاصطناعي: تقنيات التمرير عبر العمليات غير القابلة للتفاضل.

مثال (5.54-4): مقارنة بـJPEG

المعطيات: نفس معدّل البِتّات. الحل: الخطوة 1: الضغط العصبي يتفوّق في PSNR/SSIM بنسب ملحوظة (غالباً 10–30٪ بتّات أقل). النتيجة: تحسّنٌ حقيقي. الربط بالذكاء الاصطناعي: لكن التكلفة الحسابية أعلى.

مثال (5.54-5): المقاييس الإدراكية

المعطيات: نموذجان بنفس MSE. الحل: الخطوة 1: الأفضل بـLPIPS قد يبدو «أدقّ» للعين وإن كان أسوأ بـMSE. النتيجة: اختيارُ المقياس يحدّد النتيجة. الربط بالذكاء الاصطناعي: «perceptual loss» اتجاهٌ معاصر.

مثال (5.54-6): الضغط التوليدي

المعطيات: معدّل منخفض جدّاً. الحل: الخطوة 1: المُفكِّك «يخترع» التفاصيل ⇒ صورة مقنعة لكنها ليست الأصل. النتيجة: مفاضلة الإخلاص مقابل الإقناع. الربط بالذكاء الاصطناعي: يربط الضغط بالنماذج التوليدية (الفصل 41).

مثال (54.5-7): تكلفة العتاد

المعطيات: مُرمِّز عصبي على هاتف. الحل: الخطوة 1: ملايين العمليات لكلّ إطار ⇒ تحدٍّ للطاقة والحرارة. النتيجة: العائق العملي الأكبر. الربط بالذكاء الاصطناعي: كفاءة الاستدلال شرطُ الاعتماد الصناعي.

مثال (54.5-8: ترميز الفيديو)

المعطيات: تسلسل إطارات. الحل: الخطوة 1: نستخدم معلومات الإطار السابق (ترميز تفاضلي) ⇒ توفير هائل. النتيجة: الضغط العصبي للفيديو مجال نشط. الربط بالذكاء الاصطناعي: التنبؤ الحركي يبقى الفكرة المركزية.

مثال (54.5-9): التمثيل الكامن ضغطاً

المعطيات: نموذج مُدرَّب ذاتياً (8.53). الحل: الخطوة 1: نضغط في فضائه الكامن ⇒ استفادة من المعنى. النتيجة: ضغطٌ «دلالي». الربط بالذكاء الاصطناعي: وحدةُ التمثيل والضغط (4.54-9).

مثال (54.5-10): حدود معلوماتية

المعطيات: نريد ضغطاً بلا فقدان. الحل: الخطوة 1: الحدّ هو إنتروبيا المصدر ⇒ لا خوارزمية تتجاوزه. النتيجة: سقفٌ نظري (الفصل 28). الربط بالذكاء الاصطناعي: معرفةُ الحدّ تمنع مطالب مستحيلة.

مثال (54.5-11): ضغط النماذج أنفسها

المعطيات: أوزان شبكة ضخمة. الحل: الخطوة 1: تكميمٌ وتقليمٌ وضغط إنتروبي ⇒ الأدوات نفسها. النتيجة: الضغط العصبي يضغط النماذج أيضاً. الربط بالذكاء الاصطناعي: نشرُ النماذج على الأجهزة الطرفية.

مثال (54.5-12): توزيع البِتّات

المعطيات: مناطق الصورة تختلف أهمية. الحل: الخطوة 1: تخصيصٌ متكيّف للبِتّات ⇒ مزيدٌ للوجوه والحوافّ وأقلّ للخلفيات. النتيجة: ضغطٌ ذكي. الربط بالذكاء الاصطناعي: آلية الانتباه تؤدي هذا الدور عمليّاً.

مثال (54.5-13): التقييم العادل

المعطيات: مقارنة مرمِّزات. الحل: الخطوة 1: نقارن على نفس BD-rate ونفس العتاد، لا على PSNR وحده. النتيجة: منهجية التقييم حاسمة. الربط بالذكاء الاصطناعي: درسٌ عام في تقييم النماذج.

مثال (14-5.54): الجاهزية الصناعية

المعطيات: معيار MPEG/AV1 مقابل عصبي. الحل: الخطوة 1: المعايير تسبق الأبحاث بسنوات؛ والتبنّي يحتاج توحيداً. النتيجة: الجاهزية مسألةُ زمن وتوحيد. الربط بالذكاء الاصطناعي: مسارُ الانتقال من البحث إلى الصناعة.

مثال (15-5.54: الخلاصة المعلوماتية)

المعطيات: كلّ خطوة ضغط. الحل: الخطوة 1: تحويل ⇒ كمّ ⇒ ترميز: ثلاث خطوات يقابلها تمثيل وفقدان وإنتروبيا. النتيجة: نظريةُ المعلومات لُغة الضغط كلّه. الربط بالذكاء الاصطناعي: يغلق حلقة الجزء الخامس مع هذا الجزء.

أخطاء شائعة

١. **تحسين MSE وحده:** قد يضرّ الإدراك.

٢. **نسيان أن التكميم هو مصدر الفقد:** لا التحويل.

٣. **مقارنة المرمِّزات بـPSNR فقط:** غير عادل.

٤. **تجاهل تكلفة العتاد:** العائق الحقيقي للتبنّي.

٥. **توقّع كسر حدّ الإنتروبيا:** مستحيل معلوماتيّاً.

تمهيد استفهامي

ماذا لو استطعنا حساب تحويل فوريه لـN نقطة بـ$O(\log^2 N)$ بوابة بدل $O(N \log N)$؟ هذا وعد **تحويل فوريه الكمّي** (QFT) — التسريع الأُسّي الشهير الذي يقوم عليه جزءٌ من وعد الحوسبة الكمّية.

لكنّ الوعد يصطدم بحاجزٍ عملي قاسٍ: النتيجة الكمّية **لا تُقرأ مجّاناً**. فقياس الحالة يدمرها، واستخراج طيفٍ كامل يتطلّب قياسات كثيرة تكلف ما وفّرناه. لذا فإنّ «معالجة الإشارة الكمّية» (QSP) اليوم أقرب إلى إطارٍ نظري وإلى خوارزميات هجينة: تحضيرُ حالة، ومعالجةٌ كمّية، ثم قراءةٌ لمعلوماتٍ مخصوصة (مثل تقدير طور) لا للطيف كله.

الموقف الصادق: المنطقة واعدة، لكنّ تفوّقها العملي اليوم غير محسوم — وكلّ ادّعاءٍ بتسريع شامل يجب أن يُسأل عن تكلفة القراءة.

صياغة رسمية

$$\mathrm{QFT}|j\rangle = \frac{1}{\sqrt{N}} \sum_{k=0}^{N-1} e^{2\pi i j k/N} |k\rangle \tag{1.6.54}$$

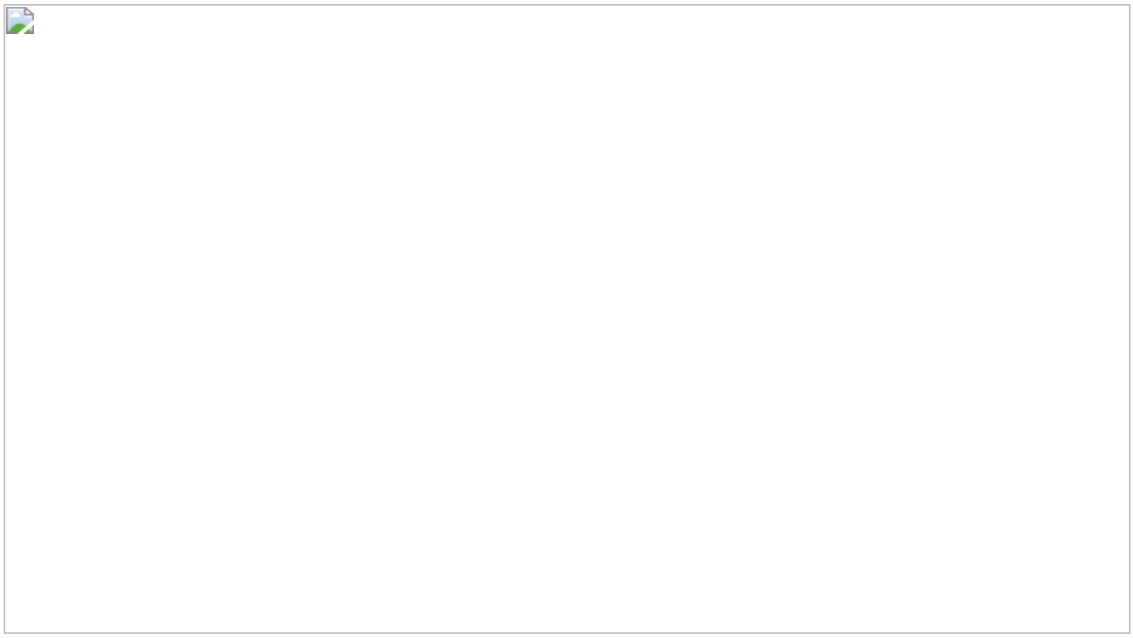
كلاسيكياً $O(N \log N)$ بوابة مقابل $O(\log^2 N)$ التكلفة: (2.6.54)

$$\text{(QPE): يستخرج تقدير الطور } \theta \text{ من } U|u\rangle = e^{2\pi i\theta}|u\rangle \text{ بدقة } m \text{ بـ بِتّات } O(2^m) \tag{3.6.54}$$

$$|x\rangle = \frac{1}{\|x\|}\sum_i x_i|i\rangle \quad \text{(مكلّف — عنق زجاجة)} \text{ تحضير الحالة:} \tag{4.6.54}$$

جدول الرموز

الرمز	المعنى	ملاحظة
QFT	تحويل فوريه كمّي	وحدة البناء
m	عدد بِتّات الدقة في تقدير الطور	يحدّد التكلفة
QPE	تقدير الطور الكمّي	أشهر تطبيق
$\|x\rangle$	حالة كمّية تمثّل الإشارة	تحضيرها مكلّف
$O(\log^2 N)$	تكلفة البوابات	مقابل كلاسيكي أكبر



شكل ٥٤.٥٤: *
معالجة الإشارة الكمية: QFT وتكلفة القراءة مقابل التسريع النظري

برهان (مخطط)

١. **(1.6.54)** QFT تطبيقٌ خطّي على قاعدة الحساب ⇒ تحويلٌ وحدوي.

٢. **(2.6.54)** تنفيذه بشبكة من بوابات الهادامارد ودورانات الطور المضبوطة ⇒ عمق $O(\log N)$ بعدد بوابات $O(\log^2 N)$.

٣. **(3.6.54)** باستخدام QFT العكسي على سجلّ البِتّات ⇒ استخراج الطور بدقة m.

٤. **(4.6.54)** تحضير حالةٍ تمثّل N قيمة كلاسيكية يتطلّب دوائر عميقة (أو ذاكرة كمّية QRAM ⇒ عنق زجاجة يلغي المكسب في كثيرٍ من التطبيقات. ■

شروط الصحّة: التسريع يقع على **البوابات** لا على الزمن الكلّي إن أضفنا التحضير والقراءة؛ ومعالجة الإشارة على حواسيب NISQ محدودة بالضجيج وعمق الدوائر.

أمثلة محلولة (15)

مثال (6.54-1): مقارنة التكلفة

المعطيات: $N = 2^{20}$. الحل: الخطوة 1: FFT $\approx 2 \times 10^7$ عملية، وQFT ≈ 400 بوابة $\Rightarrow$ فرقٌ هائل نظرياً. النتيجة: الوعد الكبير. الربط بالذكاء الاصطناعي: لكن القراءة تُكلّف (المثال التالي).

مثال (6.54-2): تكلفة القراءة

المعطيات: نريد الطيف كاملاً (N قيمة). الحل: الخطوة 1: استخراج N قيمة من الحالة يحتاج $O(N)$ قياسات $\Rightarrow$ المكسب يتبخّر. النتيجة: التسريع مشروط بمخرجات قليلة. الربط بالذكاء الاصطناعي: درسٌ عام: المكسب يقاس على المسألة لا على اللبنة.

مثال (6.54-3: تقدير الطور)

المعطيات: نريد تردّداً واحداً بدقة 10 بِتّات. الحل: الخطوة 1: QPE بـ2^{10} تكرار $\Rightarrow$ استخراج مباشر $\Rightarrow$ مكسب حقيقي. النتيجة: التطبيق المفضّل للكمّ. الربط بالذكاء الاصطناعي: نظيرُه «حساب مخصوص لا تحويل كامل».

مثال (6.54-4): تحضير الحالة

المعطيات: إشارة بـ$N = 10^6$. الحل: الخطوة 1: تحضير حالتها قد يكلّف أكثر من FFT نفسها $\Rightarrow$ عنق زجاجة معروف. النتيجة: المكسب مشروط بوصول بياناتٍ سريع (QRAM افتراضي). الربط بالذكاء الاصطناعي: الافتراضات المخفيّة تُفسد التحليل.

مثال (6.54-5): البحث بفوريه (إلهام لا تنفيذ)

المعطيات: خوارزمية Shor تستخدم QFT. الحل: الخطوة 1: لا نحتاج قراءة الطيف بل إيجاد دورته $\Rightarrow$ المكسب حقيقي هناك. النتيجة: التطبيقات المصمّمة بعناية هي الرابحة. الربط بالذكاء الاصطناعي: تصميمُ الخوارزمية حول نقاط قوة المنصّة.

مثال (6.54-6): المحاكاة الكمّية للأنظمة

المعطيات: محاكاة معادلة شرودنجر. الحل: الخطوة 1: طبيعيٌّ للكمّ لا للكلاسيكي $\Rightarrow$ مجال التفوّق الأوضح. النتيجة: «AI for Science» يلتقي بالكمّ. الربط بالذكاء الاصطناعي: حقولٌ مشتركة بين الفيزياء والتعلّم.

مثال (6.54-7): التعلّم الآلي الكمّي

المعطيات: مصنّف خطّي كمّي. الحل: الخطوة 1: تسريعٌ في أبعاد مخصوصة؛ لكن تحضير البيانات يكلّف ⇒ النتيجة مختلطة. النتيجة: تقييمٌ نقدي مطلوب. الربط بالذكاء الاصطناعي: لا تُعمَّم الوعود بلا حساب التكلفة الكلّية.

مثال (6.54-8): مرشّح كمّي

المعطيات: نريد تطبيق $g(\omega)$ على الطيف. الحل: الخطوة 1: نطبّق المرشّح على الحالة بلا قراءة ⇒ نتجنّب عنق القراءة. النتيجة: الترشيح أصلح من «قراءة الطيف». الربط بالذكاء الاصطناعي: نفس الدرس: لا تقرأ ما لا تحتاجه (6.54-3).

مثال (6.54-9): الضجيج وعمق الدائرة

المعطيات: حاسوب NISQ بضجيج. الحل: الخطوة 1: الدوائر العميقة تتراكم أخطاؤها ⇒ QFT العميق غير عملي حالياً. النتيجة: حدود العتاد الحالي. الربط بالذكاء الاصطناعي: تصحيحُ الخطأ شرطُ المستقبل.

مثال (6.54-10): التهجين الكلاسيكي-الكمّي

المعطيات: خوارزمية VQE/QAOA. الحل: الخطوة 1: الكلاسيكي يضبط والكمّي يقيس توقّعات ⇒ استفادة محدودة اليوم. النتيجة: التهجين هو الواقع العملي. الربط بالذكاء الاصطناعي: نظيرُه التعلّم الهجين (نموذج + محاكاة).

مثال (6.54-11): المعالجة التناظرية بديلاً

المعطيات: حسابٌ تناظري في مجال التردّد (بصريات/موّجات). الحل: الخطوة 1: فيزياءُ تحسب الالتفاف/التحويل مجّاناً بالانتشار ⇒ طاقة أقلّ بكثير. النتيجة: بديلٌ آخر «خارج فون نيومان». الربط بالذكاء الاصطناعي: الحوسبة التناظرية/البصرية اتجاه موازٍ.

مثال (6.54-12: أثر على التعلّم العميق)

المعطيات: تدريب شبكة ضخمة. الحل: الخطوة 1: لا تسريع كمّي عام معروف لتدريب الشبكات ⇒ ادّعاءات بلا أساس. النتيجة: الحذر من الوعود. الربط بالذكاء الاصطناعي: التفكير النقدي جزءٌ من الثقافة العلمية.

مثال (6.54-13): التحويلات الأخرى كمّياً

المعطيات: تحويل هادامارد/جيب. الحل: الخطوة 1: تسريعات مشابهة متاحة ⇒ أدوات أوسع. النتيجة: مكتبة كمّية للإشارات تتشكّل. الربط بالذكاء الاصطناعي: المميّزات الكمّية مجال بحث.

مثال (14-6.54): معايير المقارنة

المعطيات: ادّعاء تسريع أُسّي. الحل: الخطوة 1: نسأل: تحضير؟ قراءة؟ ضجيج؟ ⇒ كثير من الادّعاءات يتهاوى. النتيجة: قائمةُ فحص نقدية. الربط بالذكاء الاصطناعي: منهجية التقييم (كما في 13-5.54).

مثال (15-6.54): الموقف الراهن

المعطيات: أين نحن اليوم؟ الحل: الخطوة 1: إطارٌ نظري قوي + تطبيقات مخصوصة واعدة + عتاد لم ينضج. النتيجة: استثمارٌ في الفهم لا في الوعود. الربط بالذكاء الاصطناعي: تعلّمُ الأساس يبقى نافعاً أيّاً كان المستقبل العتادي.

أخطاء شائعة

١. **نسيان تكلفة التحضير والقراءة:** يلغي التسريع غالباً.

٢. **تعميم نتائج QPE على كلّ المعالجة:** مشروط.

٣. **تجاهل ضجيج NISQ:** الأعماق الكبيرة غير عملية.

٤. **الخلط بين البوابات والزمن الكلّي:** مختلفان.

٥. **قبول الوعود التسويقية بلا حساب التكلفة الكلّية.**

تمهيد استفهامي

الكاميرا العادية تُرسل إطاراً كاملاً 30 مرّة في الثانية — معظمه لم يتغيّر. أمّا **الكاميرا الحدثية** (event camera) فلا تُرسل إطاراً: تُرسل **تغيّراً** عند كلّ بكسل يتجاوز شدّته عتبة — بزمن وصولٍ بالميكروثانية، وبمعدّل بياناتٍ أخفض بمراتب في المشاهد الساكنة.

هذا يقلب نظرية العيّنات رأساً على عقب: العيّنات **غير منتظمة**، ومعدّلها **متكيّف بالمحتوى**. فلا ينطبق نيكويست بشكله الكلاسيكي، وتُستبدل به شروطٌ على «كثافة الأحداث» لكفاية التمثيل. والشبكات التي تعالج هذه البيانات (الشبكات النبضية SNN والنيورومورفيك) تعمل بالمنطق نفسه: حسابٌ مدفوع بالأحداث لا بالساعة.

صياغة رسمية

$$e = (x, y, t, p), \quad p = \pm 1 \text{ عند } |\log I(t) - \log I(t_{\text{آخر}})| > C \text{ حدث:} \tag{1.7.54}$$

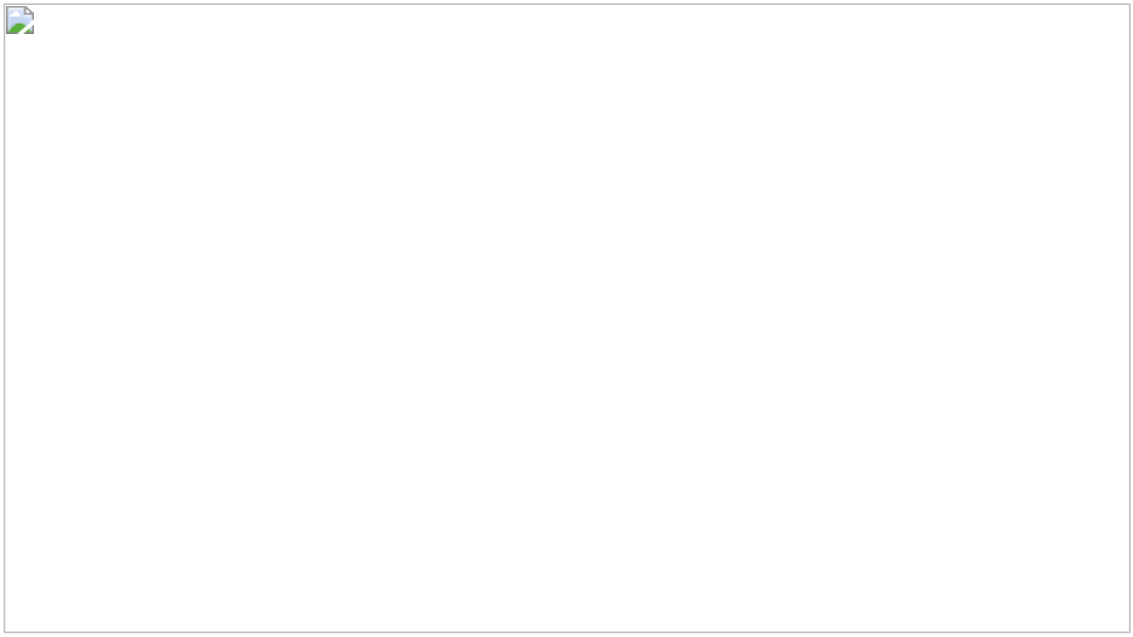
$$\lambda_e \propto \text{حدة التباين} \cdot \text{مقدار الحركة} \text{ معدّل الأحداث:} \tag{2.7.54}$$

$$V_t = \beta V_{t-1} + \sum_j w_j s_j(t), \quad s = 1 \text{ عند } V \geq V_{\text{th}} \Rightarrow V \leftarrow V - V_{\text{th}} \text{ SNN (تكامل وتفريغ):} \tag{3.7.54}$$

(4.7.54) لا تنطبق بلا تعميم $x(t) = \sum_n x_n \,\mathrm{sinc}\left(\frac{t - t_n}{T}\right)$ العيّنات غير المنتظمة:

جدول الرموز

الرمز	المعنى	ملاحظة
e	حدث (موضع وزمن وقطبية)	وحدة البيانات
C	عتبة التباين	تحدّد الحساسية
V_t	جهد الغشاء في العصبون النبضي	ذاكرة قصيرة
V_{th}	عتبة الإطلاق	يشعل النبضة
β	معامل التلاشي	يحدّد الذاكرة



شكل ٦٠٥٤: *
الاستشعار الحدثي: عينات عند التغير فقط بدل إطارات دورية

برهان (مخطط)

١. **(1.7.54)** المستشعر يقارن اللوغاريتم بالقيمة الأخيرة ⇒ حدثٌ عند تجاوز العتبة (لاخطّية طبيعية تضغط المدى الديناميّ).

٢. **(2.7.54)** معدّل الأحداث يتناسب مع سرعة التغيّر ⇒ بيانات متكيّفة بالمحتوى.

٣. **(3.7.54)** نموذج تكامل-وتفريغ: تراكُمٌ ثم إطلاق ⇒ ترميزٌ بالمعدّل/الزمن.

٤. **(4.7.54)** إعادة البناء الكلاسيكية بـsinc تفترض شبكة منتظمة ⇒ مع الأحداث نحتاج صيغاً معمّمة (نظرية العيّنات غير المنتظمة). ■

شروط الصحّة: الأحداث لا تحمل القيمة المطلقة (فقط التغيّر) ⇒ «إطار» ساكن لا يُنتج أحداثاً ⇒ نحتاج دمجاً مع مصدرٍ آخر لاستعادة السطوع المطلق.

أمثلة محلولة (15)

مثال (54.7-1): توفير البيانات في مشهد ساكن

المعطيات: كاميرا ثابتة ومشهد شبه ساكن. الحل: الخطوة 1: معدّل أحداث منخفض جدّاً مقابل 30 إطاراً/ث ⇒ توفير بمراتب. النتيجة: كفاءةٌ هائلة. الربط بالذكاء الاصطناعي: مثالي للتطبيقات منخفضة الطاقة.

مثال (54.7-2): حركة سريعة جدّاً

المعطيات: جسم يتحرك بسرعة عالية. الحل: الخطوة 1: الكاميرا العادية تموّه الحركة؛ والحدثية تسجّل الأحداث بدقة ميكروثانية ⇒ بلا تموّه. النتيجة: ميزةٌ زمنية حاسمة. الربط بالذكاء الاصطناعي: الروبوتات السريعة والمركبات.

مثال (54.7-3): المدى الديناميّ

المعطيات: مشهد بظلال قاسية وإضاءة ساطعة. الحل: الخطوة 1: اللوغاريتم في (54.7-1) ⇒ مدى دينامي >120 dB. النتيجة: رؤيةٌ في ظروف قاسية. الربط بالذكاء الاصطناعي: القيادة الذاتية ليلاً وفي الأنفاق.

مثال (54.7-4): غياب القيمة المطلقة

المعطيات: نريد سطوع البكسل. الحل: الخطوة 1: الأحداث تعطي التغيّر فقط ⇒ ندمج مع إطار أو نتراكم. النتيجة: قيدٌ تصميمي. الربط بالذكاء الاصطناعي: أهميةُ فهم طبيعة البيانات قبل اختيار النموذج.

مثال (54.7-5): شبكة نبضية (SNN)

المعطيات: حسابٌ مدفوع بالأحداث. الحل: الخطوة 1: كلّ حدث يُحدّث العصبونات المتصلة ⇒ طاقة تتناسب مع النشاط لا مع الزمن. النتيجة: كفاءة طاقة عالية. الربط بالذكاء الاصطناعي: الحوسبة الطرفية والمستشعرات الذكية.

مثال (54.7-6): التدريب بالانتشار العكسي في الزمن

المعطيات: النبضات غير قابلة للتفاضل. الحل: الخطوة 1: نستخدم تدرّجات «بديلة» (surrogate) أو ترميزاً بالمعدّل ⇒ تدريب ممكن. النتيجة: تقنيةٌ أساسية. الربط بالذكاء الاصطناعي: نظيرُ تمرير التكميم في الضغط (54.5-3).

مثال (54.7-7): ترميز بالمعدّل مقابل بالزمن

المعطيات: تمثيل قيمةٍ بنبضات. الحل: الخطوة 1: بالمعدّل: عدد نبضات في نافذة؛ وبالزمن: لحظة النبضة الأولى ⇒ أسرع وأوفر. النتيجة: ترميزات مختلفة لمهام مختلفة. الربط بالذكاء الاصطناعي: «time-to-first-spike» شائع في

الرؤية السريعة.

مثال (7.54-8): العيّنات غير المنتظمة وإعادة البناء

المعطيات: أوقات أحداث غير منتظمة. الحل: الخطوة 1: نستخدم نظرية العيّنات غير المنتظمة (frames في فضاءات هيلبرت) بشروط كثافة. النتيجة: تعميمُ نيكويست. الربط بالذكاء الاصطناعي: مرونةُ النظريات الكلاسيكية عند تعميمها.

مثال (7.54-9): تمثيل الأحداث للشبكات

المعطيات: سيل أحداث نريده مدخلات CNN. الحل: الخطوة 1: تراكمها في «سطح أحداث» أو فوكسل زمني ⇒ تمثيلٌ منتظم. النتيجة: جسرٌ إلى الشبكات القياسية. الربط بالذكاء الاصطناعي: هندسةُ التمثيل خطوةٌ حاسمة.

مثال (7.54-10): الضجيج في المستشعرات الحدثية

المعطيات: أحداث بضجيج في الإضاءة الخافتة. الحل: الخطوة 1: تصفيةٌ زمنية/مكانية (كما في 6.52) ⇒ تنظيف بسيط. النتيجة: أدواتنا الكلاسيكية تعمل هنا أيضاً. الربط بالذكاء الاصطناعي: وحدةُ الأدوات عبر أنماط الاستشعار.

مثال (7.54-11): التأخير المنخفض

المعطيات: تحكم روبوتي سريع. الحل: الخطوة 1: زمن وصول الحدث بالميكروثانية ⇒ حلقة تحكم سريعة جدّاً. النتيجة: تطبيقات لا تقدر عليها الكاميرات العادية. الربط بالذكاء الاصطناعي: الأنظمة الآنية تتطلّب قياساً آنياً.

مثال (7.54-12: النيورومورفيك والعتاد)

المعطيات: رقائق مثل Loihi/SpiNNaker. الحل: الخطوة 1: حسابٌ غير متزامن مدفوع بالأحداث ⇒ طاقة أقلّ بمراتب للمهام المتفرّقة. النتيجة: عتادٌ يوافق طبيعة البيانات. الربط بالذكاء الاصطناعي: العتاد والنموذج يُصمَّمان معاً.

مثال (7.54-13: متى لا تفيد الأحداث؟)

المعطيات: مشهد يتغيّر بالكامل باستمرار. الحل: الخطوة 1: معدّل أحداث عالٍ ⇒ ميزة البيانات تتلاشى. النتيجة: الحدثية ليست حلاً شاملاً. الربط بالذكاء الاصطناعي: الأداة بحسب بنية المشكلة (درس متكرّر).

مثال (54.7-14): الدمج مع الكاميرا العادية

المعطيات: نريد سطوعاً وحركة دقيقة. الحل: الخطوة 1: دمجٌ متعدد الوسائط ⇐ إطارات للسطوع وأحداث للحركة. النتيجة: أفضل من كلٍّ منفرداً. الربط بالذكاء الاصطناعي: تعدد الوسائط اتجاهٌ عام.

مثال (54.7-15: النظرة الشاملة)

المعطيات: من العيّنة الدورية إلى الحدثية. الحل: الخطوة 1: تغيّرُ نمط القياس يفرض تغيّر النظرية (نيكويست ⇐ كثافة/frames). النتيجة: النظريات تتكيّف مع العتاد. الربط بالذكاء الاصطناعي: مرونةُ الإطار الرياضي ميزةُ هذا الكتاب.

أخطاء شائعة

١. **تطبيق نيكويست على الأحداث مباشرة:** العيّنات غير منتظمة.

٢. **توقّع أن الأحداث تعطي السطوع:** تعطي التغيّر فقط.

٣. **تجاهل ضجيج الإضاءة الخافتة:** يملأ السيل بأحداث زائفة.

٤. **نسيان أن تراكم الأحداث يفقد الزمن الدقيق:** مفاضلة التمثيل.

٥. **الظنّ أن الحدثية أفضل دائماً:** مرتبطة بمعدّل التغيّر.

تمهيد استفهامي

بعد تسعة أجزاء وأربعة وخمسين فصلاً، ماذا نعرف وماذا لا نعرف؟ نعرف أنّ النماذج تتعلّم الترددات المنخفضة أولاً، وأنّ التمثيل المناسب يختصر الطريق، وأنّ للأقطاب ذاكرةً وللأطياف طاقة. لكنّنا لا نملك بعد **نظرية تعميمٍ كاملة** للنماذج العميقة على الإشارات: لماذا تعمل؟ ومتى تفشل؟ وكيف نضمنها؟

هذا القسم خريطةٌ لا خاتمة: مسارات البحث المفتوحة، والأسئلة التي تستحقّ أن تُسأل، والقواعد التي أثبتت عموميتها عبر كلّ ما سبق. وفيه نضع الكلمة الأخيرة: **تحويلٌ خطّي يحفظ الطاقة + تعلّمٌ غير خطّي في فضاء أفضل** — القاعدة التي تلخّص الجزء التاسع كلّه.

صياغة رسمية

$$\hat{y} = \mathcal{T}^{-1}\Big(g_\theta\big(\mathcal{T}(x)\big)\Big), \qquad \mathcal{T}\text{ تحويلٌ يحفظ الطاقة} \tag{1.8.54}$$

النمط الموحّد:

$$\mathbb{E}[R] \le \hat{R} + \underbrace{\mathcal{C}(\mathcal{H})/\sqrt{n}}_{\text{سعة}} + \underbrace{\text{فجوة التمثيل}}_{\text{ذيل الطيف}} \tag{2.8.54}$$

حدّ تعميم طيفي:

$$\text{ميزانية التمثيل: } \varepsilon \approx \underbrace{\sum_{k>K} |c_k|^2}_{\text{اقتطاع}} + \underbrace{\text{تحيز النموذج}}_{\text{معمارية}} + \underbrace{\text{ضجيج البيانات}} \tag{3.8.54}$$

(4.8.54)

بحسب بنية الإشارة: دوري ⇒ فوريه، متقطّع ⇒ مويجات، على رسم ⇒ لابلاسي $\mathcal{T}$اختر قاعدة التصميم:

جدول الرموز

الرمز	المعنى	ملاحظة
$\mathcal{T}$	التحويل (فوريه/مويجات/لابلاسي)	يحفظ الطاقة
g_θ	الجزء المتعلَّم	غير خطّي
$\mathcal{C}(\mathcal{H})$	سعة العائلة	من الجزء السادس
فجوة التمثيل	أثر اختيار القاعدة	من هذا الجزء
K	ميزانية المكوّنات	تُقرأ من ذيل الطيف

خريطة المستقبل: من فوريه إلى النماذج التأسيسية للإشارات

Roadmap: Fourier → foundation models for signals



الثابت عبر المراحل: تحويلٌ خطّي يحفظ الطاقة + تعلمٌ غير خطّي في فضاء أفضل.

السؤال المفتوح: ضمانات تعميم لنماذج الإشارات (حدودٌ كحدود PAC على الطيف).

شكل ٧.٥٤: *
خريطة المستقبل: من التحويلات الكلاسيكية إلى المؤثرات العصبية والنماذج التأسيسية للإشارات

برهان (مخطط)

١. **(1.8.54)** كلّ ما رأيناه (CNN، FNO، SSM، المويجات المتعلَّمة) يكتب بهذه الصيغة: تحويل ⇒ معالجة ⇒ عكس.

٢. **(2.8.54)** حدّ تعميم = خطأ تجريبي + سعة + فجوة تمثيل؛ والأخيرة جديدة تأتي من اختيار التحويل.

٣. **(3.8.54)** ميزانية الخطأ ثلاثية المصدر؛ وكلّ مصدر يُعالج بأداةٍ من هذا الكتاب.

٤. **(4.8.54)** قاعدة التصميم المستخلصة من كلّ الأمثلة السابقة. ■

شروط الصحّة: النمط الموحّد وصفي لا حكم دقيق؛ وحدّ (2.8.54) إرشادي يجمع مفاهيم من أجزاء مختلفة، وتفاصيله بحثٌ مفتوح.

أمثلة محلولة (15)

مثال (1-8.54): CNN بوصفها (1.8.54)

المعطيات: التفاف ثم لاخطّية ثم التفاف. الحل: الخطوة 1: الالتفاف «تحويل» مرشّح (لا يحفظ الطاقة بالضرورة) ⇒ الصيغة تصفه جزئيّاً. النتيجة: النمط يعمّم مع تنوّع في خصائص $\mathcal{T}$. الربط بالذكاء الاصطناعي: أطر التوحيد تساعد على المقارنة.

مثال (2-8.54): FNO بوصفها (1.8.54)

المعطيات: FFT ⇒ ضرب ⇒ عكس. الحل: الخطوة 1: $\mathcal{F}$ $\mathcal{T}$ $= g$ ضرب متعلَّم ⇒ مطابقة تامّة للنمط. النتيجة: FNO أنقى تجسيد للفكرة. الربط بالذكاء الاصطناعي: وضوحُ التصميم يسهّل التحليل.

مثال (3-8.54): GNN الطيفية بوصفها (1.8.54)

المعطيات: GFT ⇒ مرشّح ⇒ عكس. الحل: الخطوة 1: $U^\top$ $\mathcal{T}$ $= g$ مرشّح ⇒ مطابقة. النتيجة: الرسوم تدخل الإطار نفسه. الربط بالذكاء الاصطناعي: توحيدٌ عبر البنى المختلفة.

مثال (4-8.54): اختيار التحويل خطأً

المعطيات: إشارة متقطّعة وفوريه عالمي. الحل: الخطوة 1: ذيلٌ بطيء ⇒ سعة كبيرة مطلوبة ⇒ تعميم أسوأ. النتيجة: فجوة التمثيل تُدفع من ميزانية التعميم. الربط بالذكاء الاصطناعي: الاستقراء الصحيح يوفّر بيانات (3-8.53).

مثال (5-8.54): سؤال التعميم المفتوح

المعطيات: شبكة تتجاوز سعتها البيانات وتعمّم جيداً. الحل: الخطوة 1: لا جواب نهائي؛ التفسيرات: الانحياز الضمني، والهبوط المزدوج، والانتظام الضمني (الفصل 34). النتيجة: بحثٌ مفتوح. الربط بالذكاء الاصطناعي: التواضع المعرفي جزءٌ من العلم.

مثال (6-8.54): النماذج التأسيسية للإشارات

المعطيات: نموذج واحد لصوت وصورة وزمن. الحل: الخطوة 1: توحيد التمثيلات (رموز/أطياف) ⇒ نموذج متعدد الوسائط. النتيجة: الاتجاه الصناعي الراهن. الربط بالذكاء الاصطناعي: المحوّلات متعددة الوسائط اليوم.

مثال (8.54-7): الضمانات الرسمية

المعطيات: نظام حسّاس (طبي/قيادة). الحل: الخطوة 1: نحتاج حدوداً مضمونة (interval bounds/تحقّق رسمي) ⇒ لا يكفي الاختبار التجريبي. النتيجة: بحثٌ في الموثوقية. الربط بالذكاء الاصطناعي: سلامة الذكاء الاصطناعي مجالٌ متنامٍ.

مثال (8.54-8): كفاءة الطاقة

المعطيات: نموذج ضخم يعمل دائماً. الحل: الخطوة 1: الحساب المدفوع بالأحداث أو التناظري يوفّر مراتب ⇒ عودة إلى 7.54. النتيجة: الاستدامة شرطُ المستقبل. الربط بالذكاء الاصطناعي: الطاقة قيدٌ تصميمي متزايد الأهمية.

مثال (8.54-9): البيانات الاصطناعية والتحيز الطيفي

المعطيات: تدريب على بيانات مولّدة. الحل: الخطوة 1: المولّد قد يفتقر إلى تردّدات معيّنة ⇒ النموذج يرث النقص. النتيجة: تحيّزٌ ينتقل بالطيف. الربط بالذكاء الاصطناعي: جودةُ البيانات المولّدة تُقاس طيفياً.

مثال (8.54-10): التفسير الطيفي للنماذج

المعطيات: نريد أن نفهم ما تعلّمته الشبكة. الحل: الخطوة 1: نحلّل استجابتها للتردّدات ⇒ خريطة «ما تراه». النتيجة: أداة تفسير قابلة للقياس. الربط بالذكاء الاصطناعي: قابلية التفسير شرطُ الثقة.

مثال (8.54-11): الاندماج مع الفيزياء

المعطيات: معادلة معلومة وبيانات قليلة. الحل: الخطوة 1: فقدانٌ فيزيائي + تمثيل طيفي ⇒ تعميم أفضل خارج التوزيع. النتيجة: «Science for AI» (3.54). الربط بالذكاء الاصطناعي: المعرفة المسبقة تختصر البيانات.

مثال (8.54-12): ما لا نزال نجهله

المعطيات: أسئلة بلا جواب. الحل: الخطوة 1: التعميم العميق، والانتظام الضمني، وحدود التوليد، والتحكم في الطيف المتعلَّم. النتيجة: أجندة بحثية. الربط بالذكاء الاصطناعي: الأسئلة المفتوحة هي ما يبقي المجال حيّاً.

مثال (8.54-13): الدرس المنهجي

المعطيات: أداة جديدة تظهر كلّ شهر. الحل: الخطوة 1: اسأل: ما التحويل؟ ما الطاقة المحفوظة؟ ما الذيل؟ ⇒ تقييم سريع. النتيجة: عدسةٌ نقدية جاهزة. الربط بالذكاء الاصطناعي: الأساس الرياضي يسبق الأداة ويعيش بعدها.

مثال (8.54-14): القاعدة الذهبية للجزء

المعطيات: تريد تمثيل إشارة. الحل: الخطوة 1: حلّل طيفها ⇒ اختر قاعدة ⇒ اقرأ الذيل ⇒ حدّد الميزانية ⇒ قِس الخطأ. النتيجة: خمس خطوات تغني عن التجربة العمياء. الربط بالذكاء الاصطناعي: منهجيةٌ قابلة للتكرار في أيّ مشروع.

مثال (8.54-15): كلمة الختام

المعطيات: تسعة أجزاء اكتملت. الحل: الخطوة 1: من المنطق إلى الطيف، ومن المجموع إلى المؤثّر، ومن العيّنة إلى الحدث. النتيجة: الكتاب صار أداةً لا مرجعاً فقط. الربط بالذكاء الاصطناعي: القارئ الآن يملك مفردات العقد القادم.

أخطاء شائعة

١. **مطاردة الأداة ونسيان الأساس:** الأساس يعيش أطول.

٢. **تحسين المقاييس بلا فهم البنية:** نتائج هشّة.

٣. **تجاهل فجوة التمثيل في تحليل التعميم:** ناقص.

٤. **ادّعاء اكتمال النظرية:** المجال مفتوح.

٥. **نسيان التكلفة (طاقة/عتاد/زمن) في الحكم على الفكرة:** المعيار عملي دائماً.

تمارين (30)

مستوى أول:

١. احسب طيف لابلاسي لرسم مثلّث كامل K_3.

٢. احسب طاقة إشارة $(1, -1, 0)$ على مسار ثلاث عقد بصيغة الطيف.

٣. بيّن أن الإشارة الثابتة تقابل $\lambda = 0$.

٤. اكتب مرشّحاً طيفياً $g(\lambda) = 1/(1+\lambda)$ وفسّر أثره.

٥. احسب تكلفة طبقة FNO على شبكة 128^2 بـ$K = 16$.

٦. بيّن لماذا MLP ReLU تتعلّم المنخفض أولاً.

٧. اكتب ترميز فوريه لإحداثي ثنائي الأبعاد بـ$\sigma = 1$.

٨. احسب معدّل البِتّات من إنتروبيا توزيع رموز معلوم.

٩. اكتب معادلة تكامل-وتفريغ لعصبون نبضي بـ$\beta = 0.9$.

١٠. احسب عدد الأحداث لمشهد يتغيّر ٥٪ من بكسلاته كلّ 10 ms.

مستوى ثان:

١. برهن أن ChebNet برتبة K يعادل مجالاً موضعياً بـK قفزة.

٢. اشتقّ صيغة الطاقة (4.2.54) من تعريف $x^\top Lx$.

٣. برهن خطّية FNO في عدد الأوضاع المحفوظة وتكلفتها.

٤. اربط بين اقتطاع FNO وذيل طيف الحلول (استخدم 4.5.50).

٥. برهن أن SIREN تمتلك مشتقات من كلّ رتبة (بخلاف ReLU).

٦. اشتقّ منحنى المعدّل-التشويه لمصدر غاوسي بسيط.

٧. برهن حدّ (3.5.54) من نظرية الترميز المصدر.

٨. بيّن كيف يؤثّر تحضير الحالة في المكسب الكمّي.

٩. اربط بين الاستشعار الحدثي ونظرية العيّنات (ما الذي يعمّم؟).

١٠. صغ CNN في صيغة (1.8.54) وبيّن أين يختلف عن FNO.

مستوى ثالث:

١. صمّم GNN طيفية لمهمة على رسوم بأحجام مختلفة وبرّر اختيارك.

٢. صمّم FNO لمعادلة حرارة: اذكر K والعمق والتهيئة ومبرّرها من الطيف.

٣. قارن بين INR وCNN لضغط فيديو: جدول جودة/حجم/تكلفة.

٤. خطّة تقييم عادل لمرمِّز عصبي مقابل معيار صناعي.

٥. متى يكون النهج الكمّي مبرّراً؟ اكتب قائمة فحص نقدية.

٦. صمّم نظام رؤية حدثية لروبوت سريع واذكر المقايضات.

٧. اربط بين الانحياز الطيفي وظاهرة oversmoothing في GNN.

٨. كيف تقيس «فجوة التمثيل» لمعمارية على بياناتك؟

٩. اكتب مراجعةً نقدية لادّعاء تسريع أُسّي في بحثٍ عن إشارات.

١٠. صغ سؤالاً بحثياً واحداً تودّ أن تُجيب عنه بعد هذا الكتاب — وحدّد أدواته من الفصول.

ملخص الفصل

النظرية	الصيغة المحوريّة	الدرس العملي
فوريه الرسوم	$L = U\Lambda U^\top$	التردّد = قيمة ذاتية؛ والطيف خاصّ بالرسم
FNO	$\mathcal{F}^{-1}(R\,\mathcal{F}v)$	تعلّم مؤثّر وحياد الدقة
INR/SIREN	$f_\theta(p)$ بتفعيل دوري	قاعدة مناسبة تكسر التحيّز الطيفي
الضغط العصبي	$D + \lambda R$	نظرية المعلومات لغة الضغط
الإشارة الكمّية	$O(\log^2 N)$ بـQFT	التسريع مشروط بالتحضير والقراءة
الاستشعار الحدثي	أحداث عند التغيّر	نيكويست يعمّم على عيّنات غير منتظمة
النمط الموحّد	$\mathcal{T}^{-1} g_\theta \mathcal{T}$	اختر التحويل بحسب بنية الإشارة

خاتمة الجزء التاسع

بدأنا الجزء بسؤالٍ بسيط: **متى يجوز أن نجمع ما لا نهاية له؟** وانتهينا إلى نمطٍ يوحّد كلّ ما بينهما:

$$\boxed{\hat{y} = \mathcal{T}^{-1}\Big(g_\theta\big(\mathcal{T}(x)\big)\Big)}$$

تحويلٌ يحفظ الطاقة — فوريه أو مويجات أو لابلاسي — ثم جزءٌ متعلَّم يعمل في فضاءٍ أفضل. وكلّ ما تعلّمناه بين الحدّين كان تفاصيل هذا النمط: متى يتقارب، وكيف نقيّد، وأين تضيع الطاقة، وكيف نتعلّم القاعدة بدل أن نصمّمها، وكيف نقرأ الذيل لنعرف كم نحتاج من السعة.

القواعد الخمس التي يخرج بها القارئ:

١. **اقرأ الطيف قبل أن تختار النموذج** — ذيله يحدّد السعة اللازمة (8.50).

٢. **القاعدة المناسبة أرخص من البيانات الكثيرة** — مويجات للقفزات، وفوريه للنعومة، ولابلاسي للرسوم (4.8.54).

٣. **التحويل الخطّي يحفظ الطاقة، والتعلّم يعمل في الفضاء الجديد** (8.49، 1.8.54).

٤. **الاستقرار في الأقطاب، والذاكرة في الأقطاب** — المرشّحات وSSM سواء (6.49، 6.53).

٥. **حين يعجز تمثيل، بدّل التجميع قبل أن تزيد الحدود** (7.49، 6.50).

جدول الرموز (فهرس الجزء التاسع)

الرمز	المعنى	الفصل
S_N, σ_N	المجموع الجزئيّ ومجموع فيير	49، 50
D_N, K_N	نواتا ديريكله وفيير	50
a_n, b_n, c_k	معاملات فوريه	50
$X(\omega)$, $X[k]$	الطيف المتّصل والمنفصل	51
f_s, B	معدّل العيّنة وعرض النطاق	51
ψ, ϕ	المويجة ودالة القياس	52
cA, cD	تقريبات وتفاصيل DWT	52
$H(z)$	دالة تحويل المرشّح	53
A, Δ	مصفوفة الحالة وخطوة التفريد	53
L, U	لابلاسي الرسم وقاعدته	54
$\mathcal{T}$	تحويلٌ موحّد يحفظ الطاقة	54

نهاية الفصل الرابع والخمسين — وبه يتمّ الجزء التاسع، وبه يُختم هذا الكتاب المرجعي: من البذرة الأولى إلى أحدث النظريات.

الفهرس الشامل

الشعار: «الكتاب المُحكَم كتابٌ يُعرَف مواضع كنوزه.»

هذا الملحق يجمّع في مكانٍ واحد: فهرس النظريات، فهرس المعادلات المرقّمة، فهرس الرسوم التوضيحية، وفهرس الرموز الموحّد عبر جميع فصول الكتاب (54 فصلاً في 9 أجزاء). الأرقام تتطابق مع أرقام الفصول والأقسام في المتن.

إحصاءات سريعة: 289 نظرية · 868 معادلة مرقّمة · 348 رسم توضيحي مُشار إليه · 54 فصلاً.

الجزء الأول: الأسس الرياضية

العنوان	النظرية	الفصل
لامّة التبادل لشتاينيتز وثبات البُعد	2.2	الفصل 02
متراجحة كوشي–شفارتس ومتراجحة المثلث	3.2	الفصل 02
نظرية الإسقاط المتعامد وأفضل تقريب	4.2	الفصل 02
غرام–شميدت والتحليل QR	5.2	الفصل 02
نظرية الرتبة والعدمية (Rank–Nullity)	6.2	الفصل 02
التمثيل الماتريسي للتحويل الخطي وتغيير الأساس	1.3	الفصل 03
المحدد وخصائصه (Determinant)	2.3	الفصل 03
الأثر (Trace) وخصائصه الدورية	3.3	الفصل 03
المعكوس ومتطابقة وودبري (Woodbury) & Inverse (Matrix	4.3	الفصل 03
التفكك القطبي والتصنيف الهندسي للتحويلات	5.3	الفصل 03
نظرية التحليل الطيفي (Spectral Theorem) ودوال المصفوفات	2.4	الفصل 04
تحليل القيم المفردة (SVD) ونظرية إيكارت–يونغ–ميرسكي	3.4	الفصل 04
خارج قسمة رايلي وتوصيف ريلي–ريتز ومتراجحات فايل	4.4	الفصل 04
طيف لابلاس الرسم البياني، متجه فيدلر، ومتراجحة شيغير	5.4	الفصل 04
نظرية بيرون–فروبينيوس، PageRank، وتكرار القوة	6.4	الفصل 04
متراجحات كوشي–شفارتس وهولدر ومينكوفسكي، والناظم الثنوي	2.5	الفصل 05
تكافؤ النواظم في الأبعاد المنتهية وحدود التحويل	3.5	الفصل 05
النواظم المصفوفية المستحثة، التضاعف التحتي، ونصف القطر الطيفي	4.5	الفصل 05
نواظم شاتن، متراجحة فون نيومان للأثر، وازدواج النواظم المصفوفية	5.5	الفصل 05
تركّز النواظم ولمّا جونسون–ليندنشتراوس، وناظم المصفوفة العشوائية	6.5	الفصل 05
الخطأ الأمامي $\lesssim \kappa \times$ الخطأ الخلفي	2.6	الفصل 06
حدّ غولوب–ويلكنسون $\kappa(A^\top A) = \kappa(A)^2$	5.6	الفصل 06

الجزء الثاني: التفاضل والتكامل

العنوان	النظرية	الفصل
يعقوبية softmax	—	الفصل 09

الجزء الثالث: الاحتمال والإحصاء

العنوان	النظرية	الفصل
متراجحة ماركوف (Markov's Inequality)	2.17	الفصل 17
متراجحتا تشيبيشف وكانتيلي (Chebyshev & Cantelli)	3.17	الفصل 17
متراجحة تشيرنوف والدالة المولّدة (Chernoff Method) MGF /	4.17	الفصل 17
متراجحتا هافدينغ واتحاد الاحتمالات (Hoeffding Bound) Union &	5.17	الفصل 17
متراجحة برنشتاين (Bernstein's Inequality)	6.17	الفصل 17

الفصل 17	7.17	مترابحات المسيرة والفرق المحدود (Azuma / McDiarmid / Martingales)
الفصل 17	8.17	مترابحات معلوماتية: KL والانحراف المضاعف وسانوف (KL / Chernoff Multiplicative / Sanov)
الفصل 18	2.18	تقدير الاحتمال الأقصى (Maximum Likelihood Estimation)
الفصل 18	3.18	تقدير بايز الأقصى (Maximum A Posteriori)
الفصل 18	4.18	خصائص المقدّر: التحيّز، MSE، الاتساق، الكفاية
الفصل 18	5.18	المقدّر البايزي (الوسط الخلفي)
الفصل 18	6.18	فترات الثقة والتماثل التقاربي (Confidence & Asymptotics)
الفصل 18	7.18	اختبار الفرضيات (Neyman–Pearson & LRT)
الفصل 18	8.18	خوارزمية EM (Expectation–Maximization)
الفصل 19	2.19	الثبات والارتباط الذاتي (Stationarity & ACF/PACF)
الفصل 19	3.19	نماذج الانحدار الذاتي (Autoregressive Models)
الفصل 19	4.19	نماذج المتوسط المتحرّك و ARMA
الفصل 19	5.19	المشي العشوائي و ARIMA
الفصل 19	6.19	عمليات بواسون (Poisson Processes)
الفصل 19	7.19	الحركة البراونية والمعادلات التفاضلية العشوائية
الفصل 19	8.19	المارتنغيالات والتوقّف الأمثل (Martingales & Optional Stopping)

الجزء الرابع: التحسين

الفصل	النظرية	العنوان
الفصل 20	2.20	شرط الرتبة الأولى (مبرهنة فيرما)
الفصل 20	3.20	شروط الرتبة الثانية
الفصل 20	4.20	التحدّب والأمثلية العالمية
الفصل 20	5.20	السلاسة والتحدّب القوي ورقم الحالة
الفصل 20	6.20	البحث الخطّي (Line Search)
الفصل 20	7.20	هبوط التدرّج ومعدّلات التقارب
الفصل 20	8.20	نيوتن وشبه نيوتن (Newton & Quasi-Newton)
الفصل 21	2.21	مضاعفات لاغرانج (قيود المساواة)
الفصل 21	3.21	شروط كاروش–كون–تاكر (KKT)
الفصل 21	4.21	الثنائية اللاغرانجية
الفصل 21	5.21	الثنائية الضعيفة والقوية وشرط سلاتر
الفصل 21	6.21	الإسقاط والتدرّج المسقوط
الفصل 21	7.21	العقوبة ولاغرانج المعزّز
الفصل 21	8.21	التطبيقات: SVM والهامش والبرمجة التربيعية
الفصل 22	2.22	المجموعات المحدبة ونظرية الفصل
الفصل 22	3.22	الدوالّ المحدّبة والعمليات الحافظة للتحدّب
الفصل 22	4.22	التدرّج الجزئي (Subgradient)
الفصل 22	5.22	الازدواج المترافق (Fenchel Conjugate)
الفصل 22	6.22	ازدواج فنشل–روكافلر
الفصل 22	7.22	المؤثّر القريب والنزول القريب (Proximal / ISTA)
الفصل 22	8.22	التسريع FISTA والمعدّل $O(1/k^2)$
الفصل 23	2.23	الهبوط العشوائي (SGD) وتقاربه
الفصل 23	3.23	الزخم الثقيل (Heavy-Ball Momentum)
الفصل 23	4.23	تسريع نيستروف (Nesterov Accelerated Gradient)
الفصل 23	5.23	الطرق التكيّفية القطرية: AdaGrad و RMSProp
الفصل 23	6.23	Adam و AdamW
الفصل 23	7.23	تقليل التباين: SVRG و SAGA
الفصل 23	8.23	جدولة معدّل التعلّم والاختيار العملي
الفصل 24	2.24	فضاء المماسّ والتدرّج الريماني
الفصل 24	3.24	الانكماش ونقل المتّجه
الفصل 24	4.24	الهبوط التدرّجي الريماني وتقاربه
الفصل 24	5.24	الهِسّية الريمانية ونيوتن الريماني
الفصل 24	6.24	متشعّب الكرة والاتّجاهات الوحيدة
الفصل 24	7.24	متشعّب شتيفل والقيود المتعامدة
الفصل 24	8.24	متشعّب الرتبة الثابتة ومصفوفات التحديد الإيجابي
الفصل 25	2.25	التحسين الأسود (Black-Box / Derivative-Free)
الفصل 25	3.25	العمليات الغاوسية كنموذج بديل
الفصل 25	4.25	دالّة الاكتساب: التحسين المتوقّع (Expected Improvement)
الفصل 25	5.25	UCB و PI ومقايضة الاستكشاف والاستغلال
الفصل 25	6.25	الندم التراكمي وإطار bandits
الفصل 25	7.25	التحسين التوزيعي: توازي البيانات ومعلّم العاملات

الفصل 25	8.25	متوسط النماذج والتعلّم الاتحادي

الجزء الخامس: نظرية المعلومات

الفصل	النظرية	العنوان
الفصل 26	2.26	إنتروبيا شانون
الفصل 26	3.26	الإنتروبيا المشتركة والشرطية وقاعدة السلسلة
الفصل 26	4.26	المعلومات المتبادلة (Mutual Information)
الفصل 26	5.26	خصائص الإنتروبيا: الحدّ الأقصى والتقعّر والتكييف
الفصل 26	6.26	الإنتروبيا التفاضلية (Continuous)
الفصل 26	7.26	كسب المعلومات وأشجار القرار
الفصل 26	8.26	مبدأ الإنتروبيا الأعظمية والتوزيعات الأسّية
الفصل 27	2.27	إنتروبيا التقاطع (Cross-Entropy)
الفصل 27	3.27	تباعد كولباك–لايبلر (KL Divergence)
الفصل 27	4.27	خصائص KL: جيبس وعدم التماثل ومعالجة البيانات
الفصل 27	5.27	تباعدات ف–ديفرجنس (f-Divergences)
الفصل 27	6.27	الحدود التباينية: دالّة قابلة للتعلّم
الفصل 27	7.27	إنتروبيا التقاطع كخسارة: softmax والتقطير
الفصل 27	8.27	مقارنة التباعدات: JS و TV و Hellinger و Wasserstein
الفصل 28	2.28	الترميز المصدري وحدّ شانون
الفصل 28	3.28	سعة القناة (Channel Capacity)
الفصل 28	4.28	ترميز هافمان (Huffman Coding)
الفصل 28	5.28	الترميز الحسابي (Arithmetic Coding)
الفصل 28	6.28	متراجحة كرافت (Kraft Inequality)
الفصل 28	7.28	نظرية معدّل–التشويه (Rate-Distortion)
الفصل 28	8.28	مبدأ الوصف الأقصر (MDL)
الفصل 29	2.29	فضاء التوزيعات متشعّبٌ ريمانيّ، ومتر فيشر–راو
الفصل 29	3.29	التكافؤ المحلّي: تباعد KL هو نصف مربّع طول فيشر
الفصل 29	4.29	متراجحة كرامير–راو: فيشر حدٌّ لدقّة كلّ مقدّر
الفصل 29	5.29	التدرّج الطبيعي: أشدّ انحدارٍ في متر المعلومة
الفصل 29	6.29	البنية المزدوجة: إحداثيات e/m، تباعد بريغمان، والاتصالات α
الفصل 29	7.29	مسافة فيشر–راو: مترٌ حقيقيٌّ على فضاء التوزيعات
الفصل 29	8.29	الإسقاطات المعلوماتية: من EM إلى التعلّم العميق

الجزء السادس: نظرية التعلّم الإحصائي

الفصل	النظرية	العنوان
الفصل 30	2.30	إطار التعلّم الرسمي: الخطر، الخطر التجريبي، و ERM
الفصل 30	3.30	حدود التعميم الموحّدة ومبدأ تقليل الخطر البنيوي (SRM)
الفصل 30	4.30	تحليل التحيز–التباين
الفصل 30	5.30	التنظيم بوصفه تحكّماً في السعة
الفصل 30	6.30	اختيار النموذج والتحقق المتقاطع
الفصل 30	7.30	اتّساق ERM ونظرية «لا غداء مجاني»
الفصل 30	8.30	الأخطاء الثلاثة: تقريب وتقدير وتحسين
الفصل 31	2.31	التحطيم وبُعد فابنيك–تشرونِنكِس (VC)
الفصل 31	3.31	متراجحة Sauer–Shelah ودالّة النموّ
الفصل 31	4.31	مبرهنة التأسيس: حدّ التعميم ببُعد VC
الفصل 31	5.31	تعقيد Rademacher: حدود تعتمد على البيانات
الفصل 31	6.31	أرقام التغطية ومتراجحة Dudley
الفصل 31	7.31	حدود الهامش: لماذا تنجح الآلات النووية؟
الفصل 31	8.31	سعة الشبكات العصبية: أرقام صادقة
الفصل 32	2.32	إطار PAC الرسمي
الفصل 32	3.32	مبرهنة التأسيس لـ PAC: بُعد VC المنتهي ⇔ قابلية التعلّم
الفصل 32	4.32	التعلّم غير المتحيّز (Agnostic PAC)
الفصل 32	5.32	حدود سفلى لتعقيد العيّنة
الفصل 32	6.32	تعقيد العيّنة لفئات محدّدة

الفصل 32	7.32	الضعيف = القوي: التعزيز في إطار PAC
الفصل 32	8.32	التعقيد الحسابي للتعلّم
الفصل 33	2.33	الاستقرار الخوارزمي وحدّ التعميم (Bousquet–Elisseeff)
الفصل 33	3.33	التنظيم القوي ⇒ الاستقرار
الفصل 33	4.33	استقرار هبوط التدرّج العشوائي (Hardt–Recht–Singer)
الفصل 33	5.33	الاستقرار والتحقق المتقاطع
الفصل 33	6.33	استقرار الخوارزميات التكرارية
الفصل 33	7.33	الخصوصية التفاضلية ⇒ الاستقرار ⇒ التعميم
الفصل 33	8.33	الاستقرار في الشبكات العميقة ومقارنة المناهج
الفصل 34	2.34	مفارقة المعلمات الزائدة: الحفظ بلا تعلّم، والحدود الفارغة
الفصل 34	3.34	الحدود المعيارية (norm-based) / (margin): التعميم يضبطه المعيار والهامش لا عدد المعلمات
الفصل 34	4.34	حدود (PAC-Bayes): أوّل حدود غير فارغة على شبكات حقيقية
الفصل 34	5.34	حدود الضغط (compression): إن استطعت وصف الشبكة بـ k معلمات فالسعة هي k
الفصل 34	6.34	الانحياز الضمني للمُحسِّن: لماذا يختار (SGD) حلولاً تعمّم؟
الفصل 34	7.34	الهبوط المزدوج ونظام الاستيعاب: متى يكون الاستيعاب حميداً ومتى خبيثاً؟
الفصل 34	8.34	نواة التماس العصبية (NTK) ونظام العرض اللانهائي: متى تصير الشبكة انحداراً بنواة؟

الجزء السابع: رياضيات الشبكات العصبية

الفصل	النظرية	العنوان
الفصل 35	2.35	البيرسيبترون ونظرية التقارب (Novikoff)
الفصل 35	3.35	معمارية الشبكة الأمامية والتمثيل بالتركيب
الفصل 35	4.35	دوال التنشيط وخصائصها
الفصل 35	5.35	نظرية التقريب الشامل (طبقة واحدة مخفية)
الفصل 35	6.35	التقريب الشامل المحدود بالعرض (Lu) / (Hanin–Sellke)
الفصل 35	7.35	معدّل تقارب بارون
الفصل 35	8.35	فصل العمق (Telgarsky) / (Montufar)
الفصل 36	2.36	الرسم الحسابيّ والقاعدة المتسلسلة على الرسم
الفصل 36	3.36	الانتشار العكسي المصفوفيّ (اليعقوبية)
الفصل 36	4.36	الانتشار عبر التنشيط العنصري
الفصل 36	5.36	تعقيد التفاضل الآليّ العكسي
الفصل 36	6.36	حالات خاصة: الإنتروبيا+softmax التقاطعية وتطبيع الدُّفعات
الفصل 36	7.36	تلاشي وانفجار التدرج والتهيئة
الفصل 36	8.36	فحص التدرّج والاستقرار العددي
الفصل 37	2.37	الالتفام كمنتج داخليّ مُزاح وحجم المخرج
الفصل 37	3.37	الاتصال المحلّي ومشاركة الأوزان وعدد المعاملات
الفصل 37	4.37	التماثل الترجميّ: التبدّل (equivariance) والثبات (invariance)
الفصل 37	5.37	التجميع (Pooling): الأقصى والمتوسّط وحجم المخرج
الفصل 37	6.37	الحقل الاستقبالي (Receptive Field) ونموّه عبر الطبقات
الفصل 37	7.37	الانتشار العكسيّ عبر الالتفاف (im2col) / (col2im)
الفصل 37	8.37	كفاءة المتغيّرات: قابل للفصل (Separable) ومُجمَّع (Grouped) وWinograd
الفصل 38	2.38	الخلية المتكرّرة (Recurrent Cell) وحساب المعاملات
الفصل 38	3.38	الانتشار العكسيّ عبر الزمن (BPTT)
الفصل 38	4.38	التلاشي والانفجار التدريجيّ عبر الزمن
الفصل 38	5.38	خلية LSTM وبوّابات النسيان (Forget/Input/Output)
الفصل 38	6.38	خلية GRU (Gated Recurrent Unit)
الفصل 38	7.38	نموذج التشفير–فكّ التشفير (Seq2Seq) والتعلّم بالمعلّم
الفصل 38	8.38	التضمين (Embedding) والتعقيد الحسابي الكلّي
الفصل 39	2.39	الانتباه المُقاس بمُنتج النقاط (Scaled Dot-Product Attention)
الفصل 39	3.39	تعدّد الرؤوس (Multi-Head Attention)
الفصل 39	4.39	الترميز الموضعيّ الجيبيّ (Sinusoidal Positional Encoding)
الفصل 39	5.39	كتلة المحوّل: FFN المتبقّي، وتطبيع الطبقة (LayerNorm)
الفصل 39	6.39	التعقيد والقناع (Masking): حشو وسببيّ
الفصل 39	7.39	الانتباه المتقاطع (Cross-Attention) والتوليد التلقائيّ
الفصل 39	8.39	الانتباه الفعّال (Sparse Transformer) / (Linformer / Performer)
الفصل 40	2.40	تعريف نواة التماس العصبية (NTK)

الفصل 40	3.40	معادلة تطوّر التدريب (NTK Dynamics)
الفصل 40	4.40	تجميد العرض اللانهائيّ (Freezing Width) Infinite at
الفصل 40	5.40	الحلّ المغلق وتقارب الخطأ (Closed-Form Convergence) Error &
الفصل 40	6.40	علاقة NTK بـNNGP (NNGP Relation)
الفصل 40	7.40	النواة الالتفافية (ConvNTK)
الفصل 40	8.40	محدوديّة NTK والتعلّم الميزاتيّ (Limitations Learning) Feature &
الفصل 41	2.41	الحدّ السفليّ للدليل (ELBO) في VAE
الفصل 41	3.41	لعبة GAN الصغرى-الكبرى (Minimax GAN)
الفصل 41	4.41	التدفّقات التطبيعيّة (Normalizing Flows)
الفصل 41	5.41	عملية الانتشار الأماميّة (Forward Dffiusion)
الفصل 41	6.41	الانتشار العكسيّ وخسارة الضجيج (Reverse Training) & Dffiusion
الفصل 41	7.41	نماذج السكور والـSDE (Score-based Models) Generative
الفصل 41	8.41	قياس جودة التوليد (FID) / IS / (NLL)
الفصل 42	2.42	صياغة كانتوروفيتش (Kantorovich Formulation)
الفصل 42	3.42	ثنائية كانتوروفيتش–روبنشتاين (W1)
الفصل 42	4.42	الانتظام الإنتروبي وSinkhorn (Entropic OT)
الفصل 42	5.42	WGAN والناقد (Wasserstein Lipschitz GAN)
الفصل 42	6.42	مسافة W2 وخريطة Brenier (W2 Brenier Map) &
الفصل 42	7.42	تدفّق التدرّج في فضاء واسرشتاين (JKO Scheme)
الفصل 42	8.42	تباعد Sinkhorn العمليّ (Debiased Sinkhorn Divergence)

الجزء الثامن: بنى متقدّمة

الفصل	النظرية	العنوان
الفصل 43	2.43	تمثيل الرسوم: التجاور والدرجة واللابلاسي
الفصل 43	3.43	طيف اللابلاسي وطاقة ديريشليت
الفصل 43	4.43	التجميع الطيفي (Spectral Clustering)
الفصل 43	5.43	الالتفاف البيانيّ (GCN)
الفصل 43	6.43	ثبات التقليب والإزاحة في GNN
الفصل 43	7.43	GNN كتمرير رسائل وحدّ WL
الفصل 43	8.43	الانتباه البيانيّ (Graph Attention Network)
الفصل 44	2.44	عمليات ماركوف ودوالّ القيمة
الفصل 44	3.44	معادلة الأمثلية لبيلمان (Bellman Optimality)
الفصل 44	4.44	تكرار القيمة والسياسة (Value Iteration) Policy &
الفصل 44	5.44	تعلّم Q (Q-learning)
الفصل 44	6.44	تدرّج السياسة وREINFORCE
الفصل 44	7.44	الاستكشاف مقابل الاستغلال والندامة
الفصل 44	8.44	الممثّل–الناقد (Actor-Critic)
الفصل 45	2.45	الصياغة العادية وتوازن ناش
الفصل 45	3.45	نظريّة ناش للوجود
الفصل 45	4.45	الألعاب ثنائية الصفر والحدّ الأدنى-الأقصى
الفصل 45	5.45	ديناميكيات التعلّم
الفصل 45	6.45	الندامة وتقليل الندامة المضادّ (CFR)
الفصل 45	7.45	ألعاب الإمكانات والازدحام
الفصل 45	8.45	التعلم متعدد الوكلاء واللعب الذاتي
الفصل 46	2.46	المُعقّدات السطحية والمشغّل الحدّي
الفصل 46	3.46	التجان وأرقام بيتّي
الفصل 46	4.46	التجان الدائم
الفصل 46	5.46	نظريّة ثبات التجان الدائم
الفصل 46	6.46	تجميعات فيتوريس-ريبس و Čech
الفصل 46	7.46	المخطّطات (Mapper)
الفصل 46	8.46	تطبيقات TDA في التعلّم
الفصل 47	2.47	الفئات والمُقوّيات
الفصل 47	3.47	التحويلات الطبيعيّة والخصائص العالميّة
الفصل 47	4.47	الفئات المونويّدة والرسوم الشريطيّة
الفصل 47	5.47	المونادات
الفصل 47	6.47	العدسات والبصريات
الفصل 47	7.47	قواعد البيانات الفئويّة
الفصل 47	8.47	التركيبية في التعلّم والنشر العكسي كبصريّات
الفصل 48	2.48	المتشعّبات والفضاء المماسيّ

الفصل 48	3.48	المقاييس الريمانيّة والجيوديسيّة
الفصل 48	4.48	ارتباط ليفي-چيڤيتا والنقل المتوازي
الفصل 48	5.48	الانحناء
الفصل 48	6.48	التدرّج الطبيعي والهبوط الريمانيّ
الفصل 48	7.48	متشعّبات التمثيل وتعلّمها
الفصل 48	8.48	الهندسة الإحصائيّة والمعلوماتيّة

الجزء التاسع: المتسلسلات ومعالجة الإشارة

الفصل	النظرية	العنوان
الفصل 49	2.49	معايير التقارب للمتسلسلات الموجبة
الفصل 49	3.49	التقارب المطلق والشرطي وإعادة الترتيب
الفصل 49	4.49	متسلسلات القوى ونصف قطر التقارب
الفصل 49	5.49	التقارب الموحّد ومعيار M لفايرشتراس
الفصل 49	6.49	الدوال المولّدة والتحويلات الفرقية (تحويل Z)
الفصل 49	7.49	نظرية أبيل وتجميع سيزارو
الفصل 49	8.49	العموديّة — متفاوتة بيسل ومساواة بارسيفال
الفصل 50	2.50	معاملات فوريه والنظام العمودي
الفصل 50	3.50	تقارب ديريكلِه النقطي
الفصل 50	4.50	ظاهرة غيبس عند القفزات
الفصل 50	5.50	بارسيفال وطاقة الإشارة الدوريّة
الفصل 50	6.50	نواة ديريكلِه ونواة فيير والتقارب الموحّد
الفصل 50	7.50	فوريه المركّب والتماثل الهيرميتي
الفصل 50	8.50	التقريب الأمثل وخطأ الاقتطاع
الفصل 51	2.51	تحويل فوريه المتّصل وخصائصه
الفصل 51	3.51	DTFT وDFT وخوارزمية FFT
الفصل 51	4.51	نظرية العيّنات نيكويست–شانون
الفصل 51	5.51	التشويه الطيفي (Aliasing) ومكافحته
الفصل 51	6.51	مبرهنة الالتفاف والنوافذ والتسرّب
الفصل 51	7.51	طيف القدرة وفينر–خينتشين
الفصل 51	8.51	الطيف في التعلّم العميق
الفصل 52	2.52	مبدأ الريبة وحدود الدقة المزدوجة
الفصل 52	3.52	STFT والمخطوط الطيفي
الفصل 52	4.52	المويجات والتحويل المويجي المستمر
الفصل 52	5.52	التحويل المنفصل DWT والتحليل متعدد الدقة
الفصل 52	6.52	إزالة الضجيج بالعتبة
الفصل 52	7.52	توزيع فيغنر–فيل وحدوده المتقاطعة
الفصل 52	8.52	تحويل التشتّت والتمثيلات الثابتة
الفصل 53	2.53	المرشّحات الرقمية FIR/IIR وتصميمها
الفصل 53	3.53	الالتفاف ترشيحاً متعلَّماً وتكلفته
الفصل 53	4.53	الالتفاف الموسّع والحقل الاستقبالي الأُسّي
الفصل 53	5.53	الانتباه على الزمن وتعقيده وبدائله
الفصل 53	6.53	نماذج الحالة المنظّمة SSM/S4
الفصل 53	7.53	المُرمِّزات العصبية وتوليد الموجة
الفصل 53	8.53	التكبير الطيفي والتعلّم الذاتي الإشراف
الفصل 54	2.54	تحويل فوريه على الرسوم والمرشّحات الطيفية
الفصل 54	3.54	المؤثّرات العصبية الفوريه (FNO)
الفصل 54	4.54	التمثيلات الضمنية والانحياز الطيفي
الفصل 54	5.54	الضغط العصبي ومفاضلة المعدّل والتشويه
الفصل 54	6.54	معالجة الإشارة الكمّية (QSP/QFT)
الفصل 54	7.54	الاستشعار الحدثي والإشارات النبضية
الفصل 54	8.54	خريطة المستقبل وحدود النماذج

الصيغ مكتوبة بلغة LaTeX كما وردت في المتن (مقتطعة عند الطول الزائد).

الجزء الأول: الأسس الرياضية

الفصل	الوسم	الصيغة
01	(1.0.1)	{\0 \,1{\ \in P \equiv \text{False}{\{ \{\text{True},\ \in P
01	(2.0.1)	{\,\ 1 = P(\omega) \;\mid\; \Omega \in \omega ,\{\ ;\=;\ A_P
01	(3.0.1)	… \Omega = A_P^{c} = P{ A_{\neg A_Q,\qquad \cup A_P = Q{ A_{P\lor A_Q,\qquad \cap A_P = Q{ A_{P\land
01	(1.1)	Q) (\neg \lor P) (\neg \;\equiv\; Q) \land (P \neg
01	(2.1)	Q) (\neg \land P) (\neg \;\equiv\; Q) \lor (P \neg
01	(3.1)	A_i^{c{ I} \in \bigcap_{i ;\=;\ A_i\right)^{c{ I} \in \left(\bigcup_{i
01	(4.1)	A_i^{c{ I} \in \bigcup_{i ;\=;\ A_i\right)^{c{ I} \in \left(\bigcap_{i
01	(5.1)	P(x) \neg x\; \exists \;\equiv\; P(x) x\; \neg\,\forall
01	(6.1)	P(x) \neg x\; \forall \;\equiv\; P(x) x\; \neg\,\exists
01	(7.1)	B| \cap |A - |B| + |A| ;\=;\ B| \cup |A
01	(8.1)	C| B\cap |A\cap + C| |B\cap - C| |A\cap - B| |A\cap - |A|+|B|+|C| = C| B\cup |A\cup
01	(9.1)	… A_j| n{\!\!|A_i\cap i<j|e \sum_{1\le !\!\-;\ \sum_{i=1}^{n{|A_i| ;\=;\ A_i\right| \left|\bigcup_{i=1}^{n}
01	(10.1)	\sum_{i<j{\!\!\mathbb{… !\!\-;\ \sum_{i{\mathbb{P{(A_i) ;\=;\ A_i\right) \mathbb{P{\!\left(\bigcup_{i=1}^{n}
01	(11.1)	\mathbb{P{\!\left(… \;\le\; A_j) \sum_{i<j{\!\!\mathbb{P{(A_i\cap !\!\-;\ \sum_{i=1}^{n{\mathbb{P{(A_i)
01	(12.1)	… P(k+1)\,\Bigr] \Rightarrow P(k) n_0:\ \ge k \Bigl[\,\forall \wedge\ \ \text{صادقة}\,\Bigr] \Bigl[\,P(n_0)\
01	(13.1)	P(k)\,\Bigr]… \Rightarrow P(j)\bigr) \Rightarrow k > j \le n_0 j:\ \bigl(\forall n_0:\ \ge k \Bigl[\,\forall
01	(14.1)	… \text{أبناء} \bigl(\forall v:\ { \text{عقدة} \Bigl\,\forall \wedge\ P\,\Bigr]\ { \text{ورقة تحقق} \Bigl[\,\text{كل
01	(15.1)	… S,\ \in s \forall S:\ \in m \exists\, \Longrightarrow\ \ \emptyset \neq S \mathbb{N},\ \subseteq S \forall
02	(16.1)	\right\rceil \frac{n{m} \left\lceil \;\ge\; |A_j| \{1,\dots,m\}:\quad \in j \exists\,
02	(17.1)	\right\rfloor \frac{n{m} \left\flloor \;\le\; |A_j| \{1,\dots,m\{:\quad \in j \exists\,
02	(18.1)	…;\ \frac{n{m} \;\ge\; |A_j| \max_j \;\Longrightarrow\; \frac{n{m} ;\=;\ \frac{1{m{\sum_{j=1}^{m{|A_j|
01	(19.1)	h(y) = h(x) \mathcal{K{:\ \in y \neq x \exists\, \Longrightarrow\ \ |\mathcal{H{| < |\mathcal{K{|
01	(20.1)	Q{{Q{ \rightarrow P \frac{P,\qquad \textfb{MP:{\quad
01	(21.1)	P{ Q{{\neg \rightarrow P Q,\qquad \frac{\neg \textfb{MT:{\quad
01	(22.1)	R{ \rightarrow R{{P \rightarrow Q Q,\qquad \rightarrow \frac{P \textfb{HS:{\quad
01	(23.1)	P{{Q{ \neg Q,\qquad \lor \frac{P \textfb{DS:{\quad
01	(24.1)	Q{{P{ \land \frac{P \textfb{Simp:{\quad \qquad\qquad Q{ \land Q{{P \frac{P,\qquad \textfb{Conj:{\quad
01	(25.1)	R{ \lor R{{Q \lor P \neg Q,\qquad \lor \frac{P
01	(26.1)	P{{Q{ \neg Q,\qquad \lor \frac{P
01	(27.1)	… \models \Gamma \quad \Longleftrightarrow \quad \square \ \vdash_{\text{Res{{ \ \{\neg\varphi\{ \cup \Gamma
01	(28.1)	\varphi \models \Gamma \quad \Longleftrightarrow \quad \varphi \vdash \Gamma
02	(0.2)	-v;… = v \cdot\(1-) \mathfb{0{;\qquad = v 0\cdot \text{وحيد};\qquad (-v)\ \text{وحيد};\qquad \mathfb{0{\
02	(1.2)	0 = \alpha_k = \cdots = \alpha_2 = \alpha_1 \quad\Longrightarrow\quad \mathfb{0{ = v_i \sum_{i=1}^{k{\alpha_i
02	(2.2)	\text{مست}… \mathcal{B{\ \wedge\ \ V = \operatorname{span{(\mathcal{B{) \{b_1,\dots,b_n\{:\quad = \mathcal{B{
02	(3.2)	m \;\le\; k
02	(4.2)	…=;\ |\mathcal{B{_2| = |\mathcal{B{_1| \Longrightarrow\ \ V { لـ \text{أساسان} \mathcal{B{_2\ \mathcal{B{_1,\
02	(5.2)	W) \cap \dim(U ;\-;\ W \dim ;\+;\ U \dim ;\=;\ W) + \dim(U
02	(6.2)	W \dim + U \dim ;\=;\ W) \oplus \dim(U \Longrightarrow\ \ \{\mathfb{0{\{ = W \cap U
02	(7.2)	… n+1 { \text{أي} \mathbb{R{^{n{:\ { \text{وفي} k,\qquad \;\le\; \dim\operatorname{span{\{v_1,\dots,v_k\{
02	(8.2)	|u|\;|v| \;\le\; v\rangle\bigr| u,\ \bigl|\langle
02	(9.2)	[1,\,1-] \;\in\; v\rangle{{|u|\,|v|{ u,\ \frac{\langle ;\=;\ \cos\theta
02	(10.2)	u=… \text{أو}{\ v=\mathfb{0{\ \text{أو}{\ \ v \alpha = u \ffi |u|\,|v| = u,v\rangle\bigr| \bigl|\langle
02	(11.2)	\mathbb{E{[X^{2}]\;\mathbb{E{[Y^{2}] \;\le\; \bigl(\mathbb{E{[XY]\bigr)^{2}
02	(12.2)	v| - |u \le |v|\bigr| - \bigl||u| |v|,\qquad + |u| \;\le\; v| + |u
02	(13.2)	|A|_{F{\;|x| \;\le\; |A|_{\text{op{{\;|x| \;\le\; |Ax|
02	(14.2)	W \perp y) \hat - (y \qquad\Longleftrightarrow\qquad w| - W{{\arg\min{\;|y \underset{w\in ;\=;\ y \hat
02	(15.2)	A\,(A^{\top{A)^{-1{A^{\top{ ;\=;\ P_W
02	(16.2)	(A^{\top{A)^{-1{A^{\top{y ;\=;\ x^{\star{ A\,x^{\star{,\qquad ;\=;\ P_W\,y ;\=;\ y \hat
02	(17.2)	A^{\top{y ;\=;\ A^{\top{A\,x^{\star{
02	(18.2)	\operatorname{eig{(P_W)… \text{(تماثل)},\qquad P_W\ = P_W^{\top{ \text{(انعكاسية)},\qquad P_W\ = P_W^{2}
02	(19.2)	y|^{2} \hat - |y ;\+;\ y|^{2} |\hat ;\=;\ |y|^{2}
02	(20.2)	y,u_i… \sum_{i=1}^{n{\langle |y|^{2}\quad(k<n),\qquad \;\le\; y,u_i\rangle^{2} \sum_{i=1}^{k{\langle
02	(21.2)	\frac{w_1{{|w_1|{ = u_1 v_1,\qquad = w_1
02	(22.2)	\frac{w_j{{|w… ;\=;\ u_j u_i\bigr\rangle\,u_i,\qquad v_j,\ \sum_{i=1}^{j-1{\bigl\langle ;\-;\ v_j ;\=;\ w_j
02	(23.2)	{عليا بقطر موجب \text{مثلثية} R\ I_n,\qquad = Q^{\top{Q Q\,R,\qquad ;\=;\ A
02	(24.2)	0 ;\<;\ |w_j| ;\=;\ R_{jj{ (i<j),\qquad u_i\rangle\ v_j,\ \langle ;\=;\ R_{ij{
02	(25.2)	|R|_F ;\=;\ |A|_F |x|,\qquad ;\=;\ |Qx| x\in\mathbb{R{^{n{:\quad \forall
02	(26.2)	Q^{\top{y ;\=;\ Rx^{\star{
02	(27.2)	u_i بعد حساب كل \quad\text{فوراً u_i u_i\rangle v_j, \langle - v_j \leftarrow v_j i:\quad { \text{لكل
02	(28.2)	\underbrace{\dim\operatorname{im{(A){_{\text{الرتبة}… ;\+;\ nullity{{ \underbrace{\dim\ker(A){_{\text{العدمية}
02	(29.2)	n ;\=;\ \operatorname{rank{(A) ;\+;\ \operatorname{nullity{(A)
02	(30.2)	x\in… \{Ax:\ ;\=;\ \operatorname{im{(A) \mathfb{0{\},\qquad = Ax \{x\in\mathbb{R{^{n{:\ ;\=;\ \ker(A)
02	(31.2)	\dim… ;\=;\ \dim\operatorname{row{(A) ;\=;\ \operatorname{rank{(A^{\top{) ;\=;\ \operatorname{rank{(A)
02	(32.2)	\operatorname{rank{(… ;\=;\ \operatorname{rank{(A^{\top{A) \min(m,\,n),\qquad \;\le\; \operatorname{rank{(A)
02	(33.2)	\min\bigl(… \;\le\; \operatorname{rank{(AB) \;\le\; n - \operatorname{rank{(B) + \operatorname{rank{(A)
02	(34.2)	\operatorname{rank{(B) + \operatorname{rank{(A) \;\le\; \operatorname{rank{(A+B)
02	(35.2)	{وحيد \text{حلّ \ffi n = b]) \operatorname{rank{([A\mid = \operatorname{rank{(A)

... - n \} لانهائية (يبعد \text{حلول \ffi n > b]) \operatorname{rank}([A\mid = \operatorname{rank}(A) (36.2) 02
\} نلجأ للمربعات الصغرى \Longrightarrow حلّ \text{لا \ffi b]) \operatorname{rank}([A\mid > \operatorname{rank}(A) (37.2) 02
\beta\,T(v) ;\+;\ \alpha\,T(u) ;\=;\ v) \beta + u T(\alpha (1.3) 03
[T(b_j)]_{\mathcal{C}} ;\=;\ j} A_{:,\, [T]_{\mathcal{C}\leftarrow\mathcal{B}},\qquad ;\=;\ A (2.3) 03
A\,[\,v\,]_{\mathcal{B}} ;\=;\ [\,T(v)\,]_{\mathcal{C}} (3.3) 03
S(T(v)) = T)(v) (S\circ [S]\,[T],\qquad ;\=;\ T\,] [\,S\circ (4.3) 03
Q^{-1}\,A\,P ;\=;\ A' (5.3) 03
P A P^{-1} ;\=;\ A' (6.3) 03
A)\,\operatorname{vec}(B) (C^{\top}\otimes ;\=;\ \operatorname{vec}(ABC) (7.3) 03
(AC)\otimes(BD) ;\=;\ D) B)(C\otimes (A\otimes (8.3) 03
A_{i,\sigma(i)} \operatorname{sgn}(\sigma)\prod_{i=1}^{n} S_n} \sum_{\sigma\in ;\=;\ \det(A) (9.3) 03
\det(A)\,\det(B) ;\=;\ \det(AB) (10.3) 03
\frac{1}{\det(A)} ;\=;\ \det(A^{-1}) \det(A),\qquad ;\=;\ \det(A^{\top}) (11.3) 03
n}) (A\in\mathbb{R}^{n\times c^{\,n}\det(A)\quad ;\=;\ \det(cA) (12.3) 03
\det(A)\,\det(B) ;\=;\ \det\begin{bmatrix}A&C\\0&B\end{bmatrix} (13.3) 03
n = \operatorname{rank}(A) \ffi 0 \det(A)\neq \ffi \text{قابلة للعكس} A\ (14.3) 03
\bigl\|\det(A)\bigr\|\;\operatorname{Vol}(\Omega) ;\=;\ \operatorname{Vol}\bigl(T(\Omega)\bigr) (15.3) 03
\prod_{i=1}^{n}\lambda_i ;\=;\ \det(A) (16.3) 03
b } بـ \text{ j } استبدال عمودها \text{بعد A\ = A_j \frac{\det(A_j)}{\det(A)},\qquad ;\=;\ x_j (17.3) 03
x} f(x)}{\partial \frac{\partial = J_f(x) J_f(x)\bigr\|^{-1},\qquad p_X(x)\,\bigl\|\det ;\=;\ p_Y(y) (18.3) 03
J_f(x)\bigr\| \log\bigl\|\det ;\-;\ p_X(x) \log ;\=;\ p_Y(y) \log (19.3) 03
A_{ii} \sum_{i=1}^{n} ;\=;\ \operatorname{tr}(A) (20.3) 03
\operatorname{tr}(BA) ;\=;\ \operatorname{tr}(AB) (21.3) 03
\operatorname{tr}(CAB) ;\=;\ \operatorname{tr}(BCA) ;\=;\ \operatorname{tr}(ABC) (22.3) 03
A_kA_1) \operatorname{tr}(A_2\cdots ;\=;\ A_k) \operatorname{tr}(A_1A_2\cdots (23.3) 03
\prod_{i=1}^{n}\lambda_i ;\=;\ \det(A) \sum_{i=1}^{n}\lambda_i,\qquad ;\=;\ \operatorname{tr}(A) (24.3) 03
\operatorname{tr}(A) ;\=;\ \operatorname{tr}(P^{-1}AP) (25.3) 03
\sum_{ij}A_{ij}^{2} ;\=;\ \operatorname{tr}(A^{\top}A) ;\=;\ \|A\|_{F}^{2} (26.3) 03
\operatorname{tr}(A^{\top}B) ;\=;\ B\rangle_{F} A,\ \langle (27.3) 03
A}... \frac{\partial{\partial B^{\top},\qquad ;\=;\ A}\operatorname{tr}(AB) \frac{\partial{}\partial (28.3) 03
\operatorname{tr}\!\bigl(A^{-1}\,dA\bigr) ;\=;\ A\bigr) d\bigl(\log\det (29.3) 03
(A^{-1})^{\top} ;\=;\ (A^{\top})^{-1} B^{-1}A^{-1},\qquad ;\=;\ (AB)^{-1} (30.3) 03
v^{\top}A^{-1}u} ;\+;\ \frac{A^{-1}u\,v^{\top}A^{-1}}{1 ;\-;\ A^{-1} ;\=;\ uv^{\top}\bigr)^{-1} + \bigl(A (31.3) 03
A^{-1} V U\Bigr)^{-1} A^{-1} V + A^{-1}U\Bigl(C^{-1} ;\-;\ A^{-1} ;\=;\ V\bigr)^{-1} C U + \bigl(A (32.3) 03
U^{\top}A^{-1}U\Bigr)^{-1}U^{\top}A^{-1} + A^{-1}U\Bigl(I_k ;\-;\ A^{-1} ;\=;\ UU^{\top}\bigr)^{-1} + \bigl(A (33.3) 03
\} للعكس \text{قابلة VA^{-1}U\bigr)\ + \bigl(C^{-1} \text{و}\ C\ \text{و}\ A\ (34.3) 03
VA^{-1}U\bigr) + \det(A)\,\det(C)\,\det\bigl(C^{-1} ;\=;\ UCV\bigr) + \det\bigl(A (35.3) 03
-A^{}... & A^{-1}B\,S^{-1}CA^{-1} + A^{-1} \begin{bmatrix} ;\=;\ D\end{bmatrix}^{-1} & C B\\ & \begin{bmatrix}A (36.3) 03
k^{3}) + O(nk^{2} O(n^{3})\qquad\text{ووديري}: \text{مباشر}: (37.3) 03
0 \succeq \bigl(A^{\top}A\bigr)^{1/2} = P I_n,\qquad = U^{\top}U U\,P,\qquad ;\=;\ A (38.3) 03
0 \succeq \bigl(AA^{\top}\bigr)^{1/2} ;\=;\ P' P'\,U,\qquad ;\=;\ A (39.3) 03
\} موجبة \text{التحديد وحيدة P\ A\,(A^{\top}A)^{-1/2}\quad\text{وحيد},\qquad ;\=;\ U (40.3) 03
V^{\top} V\Sigma ;\=;\ P V^{\top},\qquad W ;\=;\ U (41.3) 03
Q\rVert_F - A I}{\arg\min}\;\lVert = Q^{\top}Q \underset{Q:\ ;\=;\ U (42.3) 03
\text{انعكاس} \ffi 1- = \det(U) qquad\,\{\text{يحفظ الاتجاه}) \text{تدوير} \ffi 1+ = \det(U) (43.3) 03
\underbrace{R_{\theta}}_{\text{تدوير}}\;\underbrace{\begin{bmatrix}\sigma_1&0\\0&\sigma_2\end{bmatrix}}... = A (44.3) 03
0 \neq v \lambda\,v,\qquad ;\=;\ A\,v (1.4) 04
I\bigr)\;=\;0 \lambda - p_A(\lambda)\;=\;\det\!\bigl(A (2.4) 04
A\Bigr]\;=... n\det^(1-) + \cdots + (\operatorname{tr}A)\lambda^{n-1} - p_A(\lambda)\;=\;(-1)^n\Bigl[\lambda^n (3.4) 04
\det(A) ;\=;\ \prod_{i=1}^{n}\lambda_i \operatorname{tr}(A),\qquad\qquad ;\=;\ \sum_{i=1}^{n}\lambda_i (4.4) 04
v_... \cdots\ \,v_1\ = P \operatorname{diag}(\lambda_1,\dots,\lambda_n),\quad = D P\,D\,P^{-1},\qquad ;\=;\ A (5.4) 04
...ق \text{ A \quad\Longleftrightarrow\quad i \forall \ \mathrm{alg}(\lambda_i)\ ;\=;\ \mathrm{geo}(\lambda_i) (6.4) 04]
... = \operatorname{tr}A p_B,\ = p_A \Longrightarrow\ S^{-1}AS)\ = B \text{مقلوبة}: S\ (\exists \ B \sim A (7.4) 04
\operatorname{diag}(\lambda_1,\dots,\lambda_n)\in\mathbb{R}^{... = \Lambda Q\,\Lambda\,Q^{\top},\qquad ;\=;\ A (8.4) 04
q... 1,\qquad = \|q_i\| \lambda_i\,q_i,\qquad = A\,q_i \sum_{i=1}^{n}\lambda_i\,q_i\,q_i^{\top},\qquad ;\=;\ A (9.4) 04
n} 0_{n\times ;\=;\ \cdots ;\-;\ I p_A(A)\;=\;\det(A)\cdot (10.4) 04
... = f(\Lambda) f(\lambda_i)\,q_i\,q_i^{\top},\qquad f(A)\;=\;Q\,f(\Lambda)\,Q^{\top}\;=\;\sum_{i=1}^{n} (11.4) 04
t},\dots,e^}... e^{At}\;=\;\sum_{k=0}^{\infty}\frac{(At)^k}{k!}\;=\;Q\,\operatorname{diag}\bigl(e^{\lambda_1 (12.4) 04
\;=\;\sum_{i=1}^{n}e^}... x(t)\;=\;e^{At}\,x_0 \quad\Longrightarrow\quad x_0 = x(0) A\,x(t),\quad = \dot{x}(t) (13.4) 04
A^{k}\;=\;\sum_{i=1}^{n}\lambda_i^{k}\,q_i\,q_i^{\top}\;\xrightarrow[k\to\infty]{}\;\lambda_1^{k}\,q_1q_1^{}... (14.4) 04
\operatorname{diag}(\lambda_1,\dots,\lambda_n)... = \Lambda I,\qquad = U^{*}U U\,\Lambda\,U^{*},\qquad ;\=;\ A (15.4) 04
\begin{cases... = \Sigma_{ij} I_n,\qquad = V^{\top}V I_m,\qquad = U^{\top}U U\,\Sigma\,V^{\top},\qquad ;\=;\ A (16.4) 04
1,\dots,r = i \sigma_i\,v_i,\qquad ;\=;\ A^{\top}u_i \sigma_i\,u_i,\qquad ;\=;\ A\,v_i (17.4) 04
\sum_{i=1}^{}... = \|A\|_F^2} \sigma_1,\qquad = \|A\|_2 \sum_{i=1}^{r}\sigma_i\,u_i\,v_i^{\top},\qquad ;\=;\ A (18.4) 04
... \le i \lambda_i\!\bigl(AA^{\top}\bigr),\qquad ;\=;\ \lambda_i\!\bigl(A^{\top}A\bigr) ;\=;\ \sigma_i^{2} (19.4) 04
\sum_{i=1}^{k}... = B^{\star} \sigma_{k+1},\qquad ;\=;\ B\|_2 - \min_{\operatorname{rank}(B)\,\le\,k}\|A (20.4) 04
B^{\star}... \sqrt{\sum_{i=k+1}^{r}\sigma_i^{2}},\qquad ;\=;\ B\|_F - \min_{\operatorname{rank}(B)\,\le\,k}\|A (21.4) 04
...\ & \begin{cases}1/\sigma_i, = \Sigma^{\dagger}_{ii} V\,\Sigma^{\dagger}\,U^{\top},\qquad ;\=;\ A^{\dagger} (22.4) 04
b\|_2\bigr\} - \arg\min\|Ax \in x ;\:;\ \arg\min\bigl\{\|x\|_2 ;\=;\ A^{\dagger}b ;\=;\ x^{\dagger} (23.4) 04
x,\,Ax\rangle}{\|x\|^{2}} R_A(x)\;=\;\frac{x^{\top}A\,x}{x^{\top}x}\;=\;\frac{\langle (24.4) 04

$$
\begin{aligned}
&\dots\ \min_{x\neq0}R_A(x),\qquad = \lambda_{\min} \lambda_{\min}(A)\;\le\;R_A(x)\;\le\;\lambda_{\max}(A),\qquad && (25.4) \quad 04\\
&R\dots\ S\setminus\{0\}} n-k+1}}\;\max_{x\in = S \dim \lambda_k(A)\;=\;\min_{\substack{S\subseteq\mathbb{R}^n}\\ && (26.4) \quad 04\\
&\lambda_i(A)\bigr\|\;\le\;\|E\|_2\;=\;\sigma_{\max}(E) - \bigl\|\lambda_i(A+E) && (27.4) \quad 04\\
&\lambda_i(A)\bigr)^{2}\;\le\;\|E\|_F^{2}\;=\;\sum_{i,j}E_{ij}^{2} - \sum_{i=1}^{n}\bigl(\lambda_i(A+E) && (28.4) \quad 04\\
&\lambda_1(A)\;\ge\;\lambda_1(B)\;\ge\;\lambda_2(A)\;\ge\;\lambda_2(B)\;\ge\;\cdots\;\ge\;\lambda_{n-1}(B)\;\dots && (29.4) \quad 04\\
&u_1\dots \hat \sin\theta(u_1,\ U_k)\bigr\|_F\;\le\;\frac{2\,\|E\|_F}{\delta},\qquad \hat \bigl\|\sin\Theta(U_k,\ && (30.4) \quad 04\\
&\text{ot\dots & ,0 E\\ (i,j)\in j,\ \neq i & -w_{ij}, j\\ = i & d_i, \begin{cases} = L_{ij} W,\qquad - D ;\=;\ L && (31.4) \quad 04\\
&w_{ij}\,(x_i\dots E} \sum_{(i,j)\in ;\=;\ x_j)^{2}_ - w_{ij}\,(x_i \frac{1}{2}\sum_{i,j=1}^{n} ;\=;\ x^{\top}L\,x && (32.4) \quad 04\\
&\dots ;\=;\ L \dim\ker ;\=;\ \text{\#\}متصلة مكوّنات 0,\qquad = \lambda_1 0,\qquad = L\,\mathfb{1} && (33.4) \quad 04\\
&\min_\dots ;\=;\ \frac{x^{\top}L\,x}{x^{\top}x} \mathfb{1}\}\}\ \perp x \\0 \neq \min_{\substack{x ;\=;\ \lambda_2 && (34.4) \quad 04\\
&\dots S\}\{\min\bigl(\operatorname{vol}S,\ \frac{\|\partial V\}\ S\subset h(G)\;=\;\min_{\emptyset\neq && (35.4) \quad 04\\
&\frac{h(G)^2}{2}\;\le\;\lambda_2\!\bigl(L_{\mathrm{sym}}\bigr)\;\le\;2\,h(G) && (36.4) \quad 04\\
&\operatorname{\dots D^{-1}W,\qquad - I ;\=;\ L_{\mathrm{rw}} D^{-1/2}WD^{-1/2},\qquad - I ;\=;\ L_{\mathrm{sym}} && (37.4) \quad 04\\
&\text{(تح\dots U^{\top}x\ = x \hat U\,g(\Lambda)\,U^{\top},\qquad = g(L) \Longrightarrow\ U^{\top}\ U\Lambda = L && (38.4) \quad 04\\
&\dots وله متجه ذاتي موجب قط (simple)، قيمة ذاتية بسيطة \quad\text{هي 0 ;\<;\ \|\lambda_i(A)\| \max_i ;\=;\ \rho(A) && (39.4) \quad 04\\
&\max_{i}\frac{(Ax)_i}{x_i} \;\le\; \rho(A) \;\le\; \min_{i}\frac{(Ax)_i}{x_i} && (40.4) \quad 04\\
&\dots عشوائية صف G \text{و (1-\alpha)\,P,\qquad ;\+;\ \alpha\cdot\frac{1}{n}\mathfb{1}\mathfb{1}^{\top} ;\=;\ G && (41.4) \quad 04\\
&\dots|\ \|\ \text{بسيطة، \1 = \lambda_1(G) 1,\qquad = \pi_i \sum_i 0,\qquad < \pi_i \pi\,G,\qquad ;\=;\ \pi && (42.4) \quad 04\\
&\frac{\ln(\dots \;\ge\; k 2\,(1-\alpha)^{k}\quad\Longrightarrow\quad \;\le\; \pi\bigr\|_1 - \bigl\|\pi^{}(k)} && (43.4) \quad 04\\
&\dots;\ A^{\top}h = a \ A\,a,\ = h qquad\,(\text{المتجه الذاتي} \quad(\text{مركزية} \frac{1}{\lambda_1{\,A\,c ;\=;\ c && (44.4) \quad 04\\
&\text{(N\dots \\[2pt] 0 = x \ffi 0 = \|x\| 0,\quad \ge \|x\| quad\&:\text{غير سالب ومحدّد} \text{(N1) \begin{aligned} && (1.5) \quad 05\\
&y\,\| - \|\,x ;\=;\ d(x,\,y) && (2.5) \quad 05\\
&d(\dots = d(x,y) \text{(M2)}&\quad \\ y = x \ffi 0 = d(x,y) 0,\quad \ge d(x,y) \text{(M1)}&\quad \begin{aligned} && (3.5) \quad 05\\
&\dots1\\ \infty > p \le 1 & \|x_i\|^{p}\Big)^{1/p}, \Big(\sum_{i=1}^{n} \displaystyle \begin{cases} ;\=;\ \|x\|_p && (4.5) \quad 05\\
&\|x_i\| \max_i = \|x\|_\infty x_i^{2},\qquad \sqrt{\sum_{i=1}^n = \|x\|_2 \|x_i\|,\qquad \sum_{i=1}^n = \|x\|_1 && (5.5) \quad 05]\\
&0 \succ G^\top = G x},\qquad G\, \sqrt{x^\top ;\=;\ \|x\|_G && (6.5) \quad 05\\
&\text{learning\dots \text{(Metric \Sigma^{-1}(x-y)}\qquad;\qquad \sqrt{(x-y)^\top = d_G(x,y) \text{(Mahalanobis)}\quad && (7.5) \quad 05\\
&x,\,y\dots \bigl\|\langle \\[4pt] \|x\|_2\,\|y\|_2 &\;\le\; x,\,y\rangle\bigr\| \bigl\|\langle \begin{aligned} && (8.5) \quad 05\\
&\|x\|_p\,\|y\|_q \;\le\; y\,\bigr\|_1 \odot \bigl\|\,x ;\=;\ \sum_{i=1}^{n}\bigl\|x_i\,y_i\bigr\| && (9.5) \quad 05\\
&\|y\|_p + \|x\|_p \;\le\; y\|_p + \|x && (10.5) \quad 05\\
&z,\dots 1}\langle = \max_{\|x\| ;\=;\ 1\,\bigr\} \le \|x\| ;\;;\ z,\,x\rangle \sup\bigl\{\,\langle ;\=;\ \|z\|_* && (11.5) \quad 05\\
&1 = \tfrac1q + \tfrac1p 0,\quad \ge b a, \qquad \frac{b^{q}{q}, + \frac{a^{p}{p} \;\le\; a\,b && (12.5) \quad 05\\
&\frac{1}{q}\;\|x\|_q - n^{}\,\frac{1}{p} \;\le\; \|x\|_p \;\le\; \|x\|_q && (13.5) \quad 05\\
&C\,\|x\|_\alpha \;\le\; \|x\|_\beta \;\le\; c\,\|x\|_\alpha && (14.5) \quad 05\\
&\min_{\|x\|_\dots ;\=;\ c_{\alpha\to\beta} \qquad 1}\|x\|_\beta, = \max_{\|x\|_\alpha ;\=;\ C_{\alpha\to\beta} && (15.5) \quad 05\\
&\dots\ \|x\|_\beta\ \mapsto x \text{(compact)},\qquad \text{متراصة} \{\,\1 = \|x\|_\alpha : V \in \{\,x ;\=;\ S_\alpha && (16.5) \quad 05\\
&\sqrt{s\dots \;\le\; \|x\|_1 \qquad\text{وخاصةً}\qquad \frac{1}{p}\}\,\|x\|_q, - s^{}\,\frac{1}{q} \;\le\; \|x\|_p && (17.5) \quad 05\\
&\dots;\=;\ \|x\| \qquad ;[0,1] \in \theta (1-\theta)\|y\|,\quad + \theta\|x\| \;\le\; (1-\theta)y\| + x \|\theta && (18.5) \quad 05\\
&x\|_\dots 0}\frac{\|A \ne \max_{x ;\=;\ x\|_\beta 1}\|A = \max_{\|x\|_\alpha ;\=;\ \beta} \to \|A\|_{\alpha && (19.5) \quad 05\\
&\dots = A)} \sqrt{\lambda_{\max}(A^\top = \sigma_1(A) =& \{2 \|A\|_{2\to ;\=;\ \|A\|_2 \begin{aligned} \boxed{ && (20.5) \quad 05\\
&\|A\|\,\|B\| \;\le\; B\| \|A \qquad \|A\|_{\alpha\to\beta}\,\|x\|_\alpha, \le x\|_\beta \|A && (21.5) \quad 05\\
&\lim_{k\to\infty}\bigl\|A^{}k\}\bigr\|\dots ;\=;\ \rho(A) \qquad \text{ناظم مستحث} \quad\text{لكل} \|A\| \;\le\; \rho(A) && (22.5) \quad 05\\
&\|A\|_\dots \;\le\; \|A\|_2 \qquad \sqrt{mn}\,\|A\|_{\max}, \;\le\; \sqrt{\|A\|_1\,\|A\|_\infty} \;\le\; \|A\|_2 && (23.5) \quad 05\\
&\|A\|\} - \frac{1}{1 \;\le\; \bigl\|(I-A)^{-1}\bigr\| \qquad \sum_{k=0}^{\infty}A^{k}, ;\=;\ A)^{-1} - (I && (24.5) \quad 05\\
&\kappa(A)\dots \;\le\; x\|\{\|x\|\} \frac{\|\Delta \qquad ,1 \;\ge\; \|A\|\,\bigl\|A^{-1}\bigr\| ;\=;\ \kappa(A) && (25.5) \quad 05\\
&\dots p \le 1 & \Bigl(\sum_{i=1}^{r}\sigma_i(A)^{\,p}\Bigr)^{1/p}, \displaystyle \begin{cases} ;\=;\ \|A\|_{S_p} && (26.5) \quad 05\\
&\bigl\dots ;\=;\ \sum_{i=1}^{\min(m,n)}\sigma_i(A)\,\sigma_i(B) \;\le\; B)\bigr\| \bigl\|\operatorname{tr}(A^\top && (27.5) \quad 05\\
&\bigl\|\|\dots \qquad\text{وخاصةً}\qquad \|A\|_{S_p}\,\|B\|_{S_q}, \;\le\; B)\bigr\| \bigl\|\operatorname{tr}(A^\top && (28.5) \quad 05\\
&1}\operatorname{tr}\dots \le \max_{\|B\|_2 ;\=;\ \|A\|_* \qquad \|\cdot\|_{S_q}, = \bigl(\|\cdot\|_{S_p}\bigr)^* && (29.5) \quad 05\\
&\dots \text{دالةً على} \text{ \|A\|_{S_p} \qquad [1,\infty]; \in p \forall \|A\|_{S_p}\quad ;\=;\ R^\top\|_{S_p} A \|Q && (30.5) \quad 05\\
&\dots ;\=;\ \frac{\|A\|_*^2}{\|A\|_F^2} \;\ge\; r \quad\Longrightarrow\quad \sqrt{r}\,\|A\|_F \;\le\; \|A\|_* && (31.5) \quad 05\\
&\qquad\Bigl(\text{وبصي\dots \varepsilon^{3}} - \frac{4\,\ln\!\bigl(n^{2}/\delta\bigr)}{\varepsilon^{2}} \;\ge\; k && (33.5) \quad 05\\
&\dots\ \|x\|_2^{2}, = x\|_2^{2} \mathbb{E}\|R \qquad \chi^{2}_{k}, \;\sim\; x\|_2^{2}}{\|x\|_2^{2}} \frac{k\,\|R && (34.5) \quad 05\\
&\dots - \mathbb{P}\Bigl(\bigl\|\|g\|_2 d,\qquad \sqrt \le \mathbb{E}\|g\|_2 d,\qquad = \mathbb{E}\|g\|_2^{2} && (35.5) \quad 05\\
&\mathbb{E\dots \ge \mathbb{P}\Bigl(\|W\|_2 \qquad n\bigr), \sqrt + m \sigma\bigl(\sqrt \;\le\; \mathbb{E}\|W\|_2 && (36.5) \quad 05\\
&\dots \frac{\varepsilon}{2}\bigl(\|x\|_2^{2} \;\le\; x,\,y\rangle\bigr\| \langle - y\rangle x,\,R R \bigl\|\langle && (37.5) \quad 05\\
&\dots-1) \quad\Longrightarrow\quad \ln(1/\delta)}{\varepsilon^{2}}\right) + \mathcal{O}\!\left(\frac{d_0 ;\=;\ k && (38.5) \quad 05\\
&n\bigr)\quad\text{ضروري} \Omega\!\bigl(\varepsilon^{-2}\log ;\=;\ k && (39.5) \quad 05\\
&\mathrm{op}\in\{\dots u,\qquad \|\delta\|\le y)(1+\delta),\qquad \mathrm{op}\ (x\ = y) \mathrm{op}\ \mathrm{fl}(x\ && (1.6) \quad 06\\
&\text{r\dots & \beta^{1-t} \\ (\text{أكثر الحالات}) \text{round-to-nearest & \tfrac{1}{2}\beta^{1-t} \begin{cases} = u && (2.6) \quad 06\\
&(0 (x\neq x-x\|}{\|x\|}\quad e_{\text{rel}}=\frac{\|\hat x-x\|,\qquad e_{\text{abs}}=\|\hat && (3.6) \quad 06\\
&\dots (forward)}{\qquad\Longleftrightarrow\qquad \text{أمامي} y}_{\text{تحليل} f(x)+\Delta = y \underbrace{\hat && (4.6) \quad 06\\
&x)-f(x)\|/\|f(x\dots x\|\le\varepsilon\|x\|}{\frac{\|f(x+\Delta 0}\sup_{\|\Delta \mathrm{cond}(f,x)=\lim_{\varepsilon\to && (5.6) \quad 06\\
&\kappa_2(A)=\frac{\sigma_1(A)}{\sigma_{\min}(A)} \kappa(A)=\|A\|\cdot\|A^{-1}\|,\qquad && (6.6) \quad 06\\
&\gamma_n=\frac{nu}{1-nu} \|\theta_n\|\le\gamma_n,\qquad \prod_{i=1}^{n}(1+\delta_i)^{s_i}=1+\theta_n,\qquad && (7.6) \quad 06\\
&x\|}{\|x\|}+\mathcal{O}(\varepsilon^{2}\dots \mathrm{cond}(f,x)\cdot\frac{\|\Delta \le\ y-f(x)\|}{\|f(x)\|}\ \frac{\|\hat && (8.6) \quad 06\\
&A\|}{\|A\|}\left(\frac{\|\dots \frac{\kappa(A)}{1-\kappa(A)\,\frac{\|\Delta \le\ x-x\|}{\|x\|}\ \frac{\|\hat && (9.6) \quad 06\\
&-\log_{10}\bigl(\dots \approx\ digits\ \#\text{correct \kappa(A)\,u,\qquad \approx\ err}\ \text{rel}\ \text{forward} && (10.6) \quad 06
\end{aligned}
$$

\frac{|A|_{2}}{… \= \sigma_{\min}(A)\ \= \text{singular}\bigr\}\ A\ A+\Delta A|_{2}:\ \min\bigl\{|\Delta	(11.6)	06
\kappa(… \text{متعامدة}),\qquad (Q\ \kappa_{2}(Q)=1\ A)=\kappa(A),\qquad \kappa(\alpha 1,\qquad \kappa(A)\ge	(12.6)	06
(attained)} الحدّ مُحقَّق \text{وهذا \kappa(A)\,u+\mathcal{O}(u^{2}),\qquad \le\ x-x|}{|x|}\ \frac{|\hat	(13.6)	06
… \approx\ \biggl(1+\frac{|a|+|b|}{|a-b|}\biggr)u\ \le\ \frac{\bigl|\mathrm{fl}(a-b)-(a-b)\bigr|}{|a-b|}\	(14.6)	06
\ln(1+x)=\text{log1p}… e^{x}-1=\text{expm1}(x),\quad \sqrt{x+1}-\sqrt{x}=\frac{1}{\sqrt{x+1}+\sqrt{x}},\quad	(15.6)	06
\gamma_{n-1}=\frac{(n-1)u}{1-(n… \gamma_{n-1}\sum_{i=1}^{n}|x_{i}|,\qquad \le\ s_{n}-s_{n}\bigr|\ \bigl|\hat	(16.6)	06
\bigl(2u+\mathcal{O}(nu^{2})\bigr)\sum_{i=1}^{n}|x_{i}| \le\ s_{n}-s_{n}\bigr|\ \bigl|\hat	(17.6)	06
\lceil… \approx\ \gamma_{\lceil\log_{2}n\rceil\sum_{i=1}^{n}|x_{i}|\ \le\ s_{n}-s_{n}\bigr|\ \bigl|\hat	(18.6)	06
s^{2}=\frac… S_{k}=S_{k-1}+(x_{k}-M_{k-1})(x_{k}-M_{k}),\qquad M_{k}=M_{k-1}+\frac{x_{k}-M_{k-1}}{k},\qquad	(19.6)	06
H=I-\frac{2vv^{\top}}{v^{\top}v}… e_{1},\qquad v=x-\sigma \sigma=-\operatorname{sign}(x_{1})|x|_{2},\qquad	(20.6)	06
c_{1}\,mn\,u\,|A|_{F} A|_{F}\le |\Delta R,\qquad Q\hat A=\hat A+\Delta	(21.6)	06
{\kappa(A) عن c_{2}\,n\,u\quad\text{مستقلٌّ \le\ Q-I|_{2}\ Q^{\top}\hat |\hat	(22.6)	06
|Qz|_{2}=|z|_{2},… |QA|_{F}=|A|_{F},\qquad c_{3}\,n\,u|z|_{2},\qquad |\mathrm{fl}(Qz)-Qz|_{2}\le	(23.6)	06
حدٍّ من … c_{4}\,u\,\kappa_{2}(A)+\mathcal{O}(u^{2})\quad\text{(بلا \le\ x-x|_{2}}{|x|_{2}}\ \frac{|\hat	(24.6)	06
(MGS)}}\qquad\gg\… المُعدَّل c\,n\,u\kappa(A)}_{\text{غرام–شميت Q|\approx Q^{\top}\hat \underbrace{|I-\hat	(25.6)	06
\kappa_2(A^{\top}A)=\kappa_2(A)^{2} \Longrightarrow\ \sigma_i(A^{\top}A)=\sigma_i(A)^{2}\	(26.6)	06
c\,u\underbrace{\Biggl(\kappa_2(A)\;+\;\kappa_2(A)^{2}\,\frac{|r|_2}{… \le\ x-x|_2}{|x|_2}\ \frac{|\hat	(27.6)	06
\kappa_2(A)+\kappa_2(A)^{2}\tan\… \le\ \kappa_2(A)+\kappa_2(A)^{2}\,\frac{\tan\theta}{\eta}\ \= \kappa_{LS}\	(28.6)	06
x_{\tau}|_2\le\frac{|b|}{… |\hat x_{\tau}=\sum_{\sigma_i>\tau}\frac{u_i^{\top}b}{\sigma_i}\,v_i,\qquad \hat	(29.6)	06
I)^{-1}A^{\top}b=\sum_i\underbrace{\frac{\sigma_i^{2}}{\sigma_i^{2}+\lambda}}… x_{\lambda}=(A^{\top}A+\lambda	(30.6)	06
\log_{… \text{QR/SVD}:\ \text{خانة}\qquad\text{مقابل}\qquad 2\log_{10}\kappa_2(A)\ المعادلات\text{ السوية}:\	(31.6)	06
{i>j \text{لكلِّ \ \1 |L_{ij}|\le PA=LU,\qquad	(32.6)	06
2^{\,n-1}\quad\text{(والحدّ 1\le\rho\le \rho=\frac{\max_{ij}|u_{ij}|}{\max_{ij}|a_{ij}|},\qquad مُحقَّق — م…	(33.6)	06
c\,n\,u\,\rho \le\ A|_{\infty}}{|A|_{\infty}}\ \frac{|\Delta x=b,\qquad A)\hat (A+\Delta	(34.6)	06
c\,n\,u\,\rho\,\kappa_{\infty}(A)+\mathcal{O}(u^{2}) \le\ x-x|_{\infty}}{|x|_{\infty}}\ \frac{|\hat	(35.6)	06
x_{k+1}=x_{k}+d_{k} (LU)d_{k}=P\,r_{k},\qquad \text{حلّ}\; u),\qquad {u_{r}\ge (\text{بدقة \ r_{k}=b-Ax_{k}\	(36.6)	06
\mathcal{O}(!\… \= n^{1/(n-1)}}{\ 4^{1/3}\cdots 3^{1/2}\cdot 2\cdot \sqrt{n}\cdot \le\ \rho_{\text{complete}}}\	(37.6)	06
z_j m=\max_j e^{z_j-m}},\qquad e^{z_j}}=\frac{e^{z_i-m}}}\sum_j \mathrm{softmax}(z)_i=\frac{e^{z_i}}}\sum_j	(38.6)	06
n m+\log \le\ \mathrm{LSE}(z)\ \le\ m\ e^{\,z_i-m},\qquad \mathrm{LSE}(z)=\log\sum_i e^{z_i}=m+\log\sum_i	(39.6)	06
p_y=-z_y+\mathrm{LSE}(z) \ell_{\mathrm{CE}}(z,y)=-\log \log\mathrm{softmax}(z)_i=z_i-\mathrm{LSE}(z),\qquad	(40.6)	06
\gamma_{n-1}+u\,|\mathrm{LSE}(z)|+\mathcal{O}(u… \le\ \bigl|\widehat{\mathrm{LSE}}(z)-\mathrm{LSE}(z)\bigr|\	(41.6)	06
…\,09.11} \text{fp16: z_i>\log\Omega:\ ممكن؛ لكن الحساب الخام يفيض إذا } \text{غير z_i-m>0\ } \text{الفيضان:	(42.6)	06
z_… \frac{\partial\ell_{\mathrm{CE}}}\partial z_j}=p_i(\delta_{ij}-p_j),\qquad p_i}}\partial \frac{\partial	(43.6)	06
… \Rightarrow\ L=s\,L\ \tilde qquad\,عدم ضياع التحديث u_{16}\,|w|}_{\text{شرط \ge\ w|\ \underbrace{|\Delta	(44.6)	06

الجزء الثاني: التفاضل والتكامل

الصيغة	الوسم	الفصل
|f(x)-L|<\varepsilon \Rightarrow 0<|x-a|<\delta \varepsilon>0\;\exists\delta>0:\ \forall	(1.7)	07
\lim\sqrt{f}=\sqrt{L}… (M\ne0),\qquad \lim\frac{f}{g}=\frac{L}{M}\ \ \lim(fg)=LM,\qquad M,\quad g)=L\pm \lim(f\pm	(2.7)	07
e = \lim_{n\to\infty}\left(1+\frac{1}{n}\right)^n	(3.7)	07
a^+}f(x)=f(a) a^-}f(x)=\lim_{x\to \lim_{x\to \ffi a \عند \text متصلة f\	(4.7)	07
f(c)=0 \exists\,c\in(a,b): \implies f(a)f(b)<0 C[a,b],\ f\in	(5.7)	07
N\Rightarrow|a_n-L|<\varepsilon n\ge N:\ \exists \forall\varepsilon>0\ \ffi L a_n\to	(6.7)	07
N\Rightarrow|a_m-a_n|<\varepsilon m,n\ge N:\ \exists \forall\varepsilon>0\ \ffi \text{كوشي} a_n\	(7.7)	07
L a_n\to \implies L c_n\to L,\ b_n\to c_n,\quad a_n\le b_n\le	(8.7)	07
D}|f_n(x)-f(x)|\to0 \varepsilon_n:=\sup_{x\in \ffi f f_n\rightrightarrows	(9.7)	07
\lim_{n\to\infty}f_n. \int_a^b = f_n \lim_{n\to\infty}\int_a^b	(10.7)	07
x=1\end{cases} & 1 x<1\\ & f_n(x)\to\begin{cases}0 [0,1]:\quad \text{على}\ \ f_n(x)=x^n	(11.7)	07
f'(a)=\lim_{h\to0}\frac{f(a+h)-f(a)}{h}	(1.8)	08
f'_+(a)=\lim_{h\to0^+}\frac{f(a+h)-f(a)}{h} f'_-(a)=\lim_{h\to0^-}\frac{f(a+h)-f(a)}{h},\qquad	(2.8)	08
(fg)'=f'g+fg'	(3.8)	08
fg\right)'=\frac{f'g-fg'}{g^2} \left(\frac	(4.8)	08
f'(x) \frac{d}{dx}\,g(f(x))=g'(f(x))\cdot	(5.8)	08
\sigma'(x)=\frac{e^{-x}}{(1+e^{-x})^2}=\frac{1}{1+e^{-x}}\cdot\frac{e^{-x}}{1+e^{-x}}=\sigma(x)\,(1-\sigma(x))	(6.8)	08
x)'=1-\tanh^2x (\tanh	(7.8)	08
\frac{dy}{dx}=\frac{1}{\sec^2y}=\frac{1}{1+\tan^2y}=\frac{1}{1+x^2}	(8.8)	08
}\frac{dy}{dx} معادلة جبرية لـ \text{حلّ \implies\ \frac{d}{dx}F(x,y(x))=0\	(9.8)	08
f^{(n)}(x)=\frac{d^n}{dx^n}f(x) f''(x)=\frac{d}{dx}f'(x),\qquad	(10.8)	08
}c\in(a,b) f(b)-f(a)=f'(c)\,(b-a)\quad\text{لنقطة	(11.8)	08
a_k}}… a_L}\cdot\prod_{k=2}^{L}\frac{\partial L}}\partial a_1}=\frac{\partial L}}\partial \frac{\partial	(12.8)	08
f_1}}… x_1}&\cdots&\dfrac{\partial f_1}}\partial x)=\begin{bmatrix}\dfrac{\partial f}(\mathfb J_{\mathfb	(1.9)	09
x_1^2}&\cdots&\dfrac{\partial^2f}}… x)=\nabla^2f=\begin{bmatrix}\dfrac{\partial^2f}}\partial H_f(\mathfb	(2.9)	09
f}=J_g\,J_f J_{g\circ	(3.9)	09
b) x-\mathfb b\big|^2=2A^\top(A\mathfb x-\mathfb x}\big|A\mathfb \nabla_{\!\mathfb	(4.9)	09

X=\det(X)\,X^{-1} \nabla_X\det X=X^{-1},\qquad \nabla_X\ln\det	(5.9)	09
s^\top s\,\mathfb s)-\mathfb J_{\mathrm{softmax}}=\mathrm{diag}(\mathfb	(6.9)	09
y s-\mathfb z}L=\mathfb \nabla_{\!\mathfb	(7.9)	09
}A_n\in… disjoint \mu(A_n)\quad\text{for A_n\right)=\sum_{n=1}^\infty \mu\!\left(\bigcup_{n=1}^\infty	(1.10)	10
Q\cap[0,1])=0. m(\mathbb m([a,b])=b-a,\qquad	(2.10)	10
F. A_i\in\mathcal 1_{A_i}(x),\qquad a_i\,\mathfb \phi(x)=\sum_{i=1}^k	(3.10)	10
g\,d\mu. b\int_X + f\,d\mu a\int_X = g)\,d\mu f+b (a \int_X	(4.10)	10
f. f_n\to\int \int \Longrightarrow\ g<\infty\ \int g,\ |f_n|\le \{ \text{DCT:	(5.10)	10
\text{(smooth)}. h(x)F'(x)\,dx\ \int \text{(discrete)},\qquad F_i\ h(x_i)\Delta h\,dF=\sum_i \int	(6.10)	10
P_n(x)=\sum_{k=0}^{n}\frac{f^{(k)}(a)}{k!}(x-a)^k.	(1.11)	11
M=\max|f^{(n+1)}|. \frac{M}{(n+1)!}\,|x-a|^{n+1},\quad |R_n(x)|\le	(2.11)	11
h^\top\nabla^2f(… h+\tfrac12\mathfb x)^\top\mathfb f(\mathfb x)+\nabla h)=f(\mathfb x+\mathfb f(\mathfb	(3.11)	11
E=O(h^{p+1}). generally}\quad more C\,|x-a|^{n+1}\quad\text{or |E|\le	(4.11)	11
x|}{… \kappa(x)\,\frac{|\delta f|}{|f|}\le \frac{|\delta \kappa(x)=\left|\frac{x\,f'(x)}{f(x)}\right|,\qquad	(5.11)	11
J\,\delta=-J^… }J^\top \text{GN: }x_{k+1}=x_k-\frac{f'(x_k)}{f''(x_k)}\quad(\text{1-D});\qquad \text{Newton:	(6.11)	11

الجزء الثالث: الاحتمال والإحصاء

الصيغة	الوسم	الفصل
}A… disjoint P(A_n)\quad\text{for \mathbb A_n\right)=\sum_{n=1}^\infty P\!\left(\bigcup_{n=1}^\infty \mathbb	(1.13)	13
P(X^{-1}(B)). P_X(B)=\mathbb \mathbb	(2.13)	13
b)=F_X(b)-F_X(a). P(a<X\le \mathbb x),\qquad P(X\le F_X(x)=\mathbb	(3.13)	13
P(… P(A)\mathbb B)=\mathbb P(A\cap \mathbb P(B)};\qquad B)}{\mathbb P(A\cap B)=\frac{\mathbb P(A\mid \mathbb	(4.13)	13
x\,dF_X(x). R} E[X]=\int_{\mathbb \mathbb	(5.13)	13
L^p\Rightarrow\… distribution};\qquad \text{in \Rightarrow\ probability}\ \text{in \Rightarrow\ \text{a.s.}\	(6.13)	13
k=0,1,\dots,n. P(X=k)=\binom{n}{k}p^k(1-p)^{n-k},\qquad	(1.14)	14
f(x)=\frac{1}{\sqrt{2\pi}\,\sigma}\exp\!\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).	(2.14)	14
f_X(x)f_Y(z-x)\,dx. R} f_{X+Y}(z)=\int_{\mathbb f_{X,Y}(x,y)\,dy;\qquad R} f_X(x)=\int_{\mathbb	(3.14)	14
y}… \mathfb x}{\partial \mathfb \frac{\partial x)\left|\det X}(\mathfb y)=f_{\mathfb Y}(\mathfb f_{\mathfb	(4.14)	14
x-\boldsymbol\mu)^\top… x)=\frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}}\exp\!\left(-\tfrac12(\mathfb f(\mathfb	(5.14)	14
(X\!\perp\!Y). \ M_{X+Y}(t)=M_X(t)M_Y(t)\ E[e^{tX}];\qquad M_X(t)=\mathbb	(6.14)	14
g(x)\,dF_X(x). R} E[g(X)]=\int_{\mathbb \mathbb	(1.15)	15
E[(X_i-\mu_i)(X_j-\mu_j)]. \Sigma_{ij}=\mathbb E[X]^2;\qquad E[X^2]-\mathbb \text{Var}(X)=\mathbb	(2.15)	15
\frac{\text{Var}(X)}{t^2}. t)\le E[X]|\ge P(|X-\mathbb \mathbb	(3.15)	15
R^d. x\in\mathbb \forall\mathfb \0 x\ge A\mathfb x^\top \mathfb \ffi 0 A\succcurlyeq	(4.15)	15
A^{-1}B\succcurlyeq0\quad(A\succ0). C-B^\top \ffi B^\top&C\end{pmatrix}\succcurlyeq0 \begin{pmatrix}A&B\\	(5.15)	15
E\nabla_\theta\ell\,\nabla_… I(\theta)=\mathbb I(\theta)^{-1},\qquad \text{Cov}(\hat\theta)\succcurlyeq	(6.15)	15
P(A_j)}. A_j)\mathbb P(B\mid P(A_k)}{\sum_{j}\mathbb A_k)\mathbb P(B\mid B)=\frac{\mathbb P(A_k\mid \mathbb	(1.16)	16]
p(x\mid\theta)p(\theta)\,d\theta. p(x)=\int x)=\frac{p(x\mid\theta)\,p(\theta)}{p(x)},\qquad p(\theta\mid	(2.16)	16
trials}. }n\text{ in r=\text{successes \beta+n-r),\qquad x\sim\text{Beta}(\alpha+r,\ \theta\mid	(3.16)	16
y)\Big). p(x_i\mid \Big(p(y)\prod_{i=1}^d y=\arg\max_y\ \hat	(4.16)	16
p(x_i\mid\text{Pa}(x_i)). p(x_1,\dots,x_d)=\prod_{i=1}^d	(5.16)	16
\sum_i\pi_i=1. \pi_i\ge0,\ P=\boldsymbol\pi^\top,\qquad \boldsymbol\pi^\top	(6.16)	16
x}e^{-\sum_cU_c(… Z=\sum_{\mathfb x_c)\Big),\qquad x)=\frac{1}{Z}\exp\!\Big(-\sum_{c}U_c(\mathfb p(\mathfb	(7.16)	16
عالياً }\text{ 0 X\ge a>0,\quad \qquad E[X]}{a}, \frac{\mathbb \;\le\; a) \ge P(X \mathbb	(1.17)	17
t>0 \qquad \frac{\sigma^2}{t^2}, \;\le\; t\big) P\big(|X-\mu|\ge \mathbb	(2.17)	17
E\!\left[e^{tX}\right] M_X(t)=\mathbb \qquad e^{-ta}\,M_X(t), \inf_{t>0}\ \;\le\; a) P(X\ge \mathbb	(3.17)	17
… 2\exp\!\left(-\frac{2nt^2}{(b-a)^2}\right), \;\le\; t\right) X_n-\mu\right|\ge P\!\left(\left|\bar \mathbb	(4.17)	17
\exp\!\left(-\frac{t^2}{2\big(n\sigma^2+bt/3\big)}… \;\le\; t\right) \ge X_i P\!\left(\sum_{i=1}^n \mathbb	(5.17)	17
c_k^2}\right). 2\exp\!\left(-\frac{t^2}{2\sum_{k=1}^n \;\le\; t\big) P\big(|M_n-M_0|\ge \mathbb	(6.17)	17
\exp\!\Big(-n\,D_{KL}\!\big((1+\delta)\mu\,|\,\mu… \;\le\; (1+\delta)\mu\big) \ge X_n P\big(\bar \mathbb	(7.17)	17
… \arg\max_{\theta}\; ;\=;\ L(\theta) \mathcal \arg\max_{\theta\in\Theta}\; ;\=;\ \hat\theta_{\text{MLE}}	(1.18)	18
p(x_i\mid\theta)\… \log \sum_{i=1}^n + p(\theta) \Big(\log \arg\max_{\theta}\; ;\=;\ \hat\theta_{\text{MAP}}	(2.18)	18
\text{MSE}(\hat\theta)=\mathrm{Var}(\hat\theta)… E[\hat\theta]-\theta,\qquad \text{Bias}(\hat\theta)=\mathbb	(3.18)	18
\theta\,p(X\mid\theta)\,p(\theta)\… \frac{\int ;\=;\ X] E[\theta\mid \mathbb ;\=;\ \hat\theta_{\text{Bayes}}	(4.18)	18
I(\theta_0)^{-1}\big) N\!\big(0,\; \mathcal \;\xrightarrow{d}\; \sqrt{n}\,(\hat\theta_n-\theta_0)	(5.18)	18
\hat\theta=\text{MLE} \qquad c, x}\le L(\hat\theta\mid x)}{\mathcal L(\theta_0\mid \Lambda(x)=\frac{\mathcal	(6.18)	18
… \qquad p(X,Z\mid\theta)\big], X,\theta^{(t)}{\big[\log E_{Z\mid \mathbb ;\=;\ Q(\theta\mid\theta^{(t)})	(7.18)	18
\rho(h)=\frac{\gamma(h)}{\gamma(0)} \gamma(h)=\mathrm{Cov}(X_t,X_{t+h}),\qquad E[X_t]=\mu,\qquad \mathbb	(1.19)	19
|\phi_1|<1 } ffi ثابت \text{AR(1) \qquad \varepsilon_t, + X_{t-i} \phi_i \sum_{i=1}^p + c = X_t	(2.19)	19
\Theta(L)=1+\sum_… \Phi(L)=1-\sum_{i=1}^p\phi_iL^i,\quad \qquad \Theta(L)\,\varepsilon_t, ;\=;\ \Phi(L)\,X_t	(3.19)	19
\nabla^d=(1-L)^d \qquad \Theta(L)\,\varepsilon_t, ;\=;\ X_t \Phi(L)\,(1-L)^d	(4.19)	19
t) N(t)\sim\text{Poisson}(\lambda h+o(h),\qquad P\big(N(t+h)-N(t)=1\big)=\lambda \mathbb	(5.19)	19
dX_t=\mu(X_t,t)\,dt+\sigma(X_t,t)\,dW_t N(0,\,t-s),\qquad W_t-W_s\sim\mathcal	(6.19)	19
E[M_0] E[M_\tau]=\mathbb \mathbb } صحّة: \text{وبشرط \qquad M_t, = F_t\big] \mathcal E\big[M_{t+1}\mid \mathbb	(7.19)	19

الجزء الرابع: التحسين

الفصل	الوسم	الصيغة
20	(1.20)	0 = f(x^\star) \nabla
20	(2.20)	أصغرى محلّية صارمة} \text{ x^\star \;\Longrightarrow\; 0 f(x^\star)\succ \nabla^2 f(x^\star)=0,\quad \nabla
20	(3.20)	x \forall f(x)\succcurlyeq0\ \nabla^2 \qquad\text{و}\qquad (y-x) f(x)^\top f(x)+\nabla f(y)\;\ge\;
20	(4.20)	\kappa=\frac{L}{\mu} \qquad I, L \;\preccurlyeq\; f(x) \nabla^2 \;\preccurlyeq\; I \mu
20	(5.20)	d f(x)^\top c_2\,\nabla \ge d d)^\top f(x+\eta \nabla d,\qquad f(x)^\top f(x)+c_1\eta\,\nabla d)\le f(x+\eta
20	(6.20)	\le… التحدّب: } \text{قوي f(x_k)-f^\star=O(1/k),\qquad } \text{محدّب: f(x_k),\qquad x_{k+1}=x_k-\eta\nabla
20	(7.20)	B_{k+1}=B_k-\frac{B_ks_ks_k… } \textfb{BFGS: \qquad f(x_k), f(x_k)\big)^{-1}\nabla x_{k+1}=x_k-\big(\nabla^2
21	(1.21)	h_j(x^\star)=0 \qquad ,0 = h_j(x^\star) \lambda_j\,\nabla \sum_{j=1}^m + f(x^\star) \nabla
21	(2.21)	g_i(x^\star)\le0,… \mu_i\ge0,\quad 0,\quad = g_i \sum_i\mu_i\nabla + h_j \sum_j\lambda_j\nabla + f \nabla
21	(3.21)	… g(\lambda,\mu)=\inf_x L(x,\lambda,\mu)=f(x)+\sum_j\lambda_jh_j(x)+\sum_i\mu_ig_i(x),\qquad \mathcal
21	(4.21)	d^\star=p^… \;\Rightarrow\; سلاتر + \text{محدّبة qquad\,}{دائمًا p^\star\quad\text{(ضعيفة d^\star\;\le\;
21	(5.21)	f(x_k)\big) x_{k+1}=\Pi_C\big(x_k-\eta\nabla C{|x-z|^2,\qquad \Pi_C(z)=\arg\min_{x\in
21	(6.21)	h(x)+\frac\rho2|… L_\rho(x,\lambda)=f(x)+\lambda^\top \mathcal h_j(x)^2,\qquad f(x)+\frac\rho2\sum_j \min_x
21	(7.21)	y_i\in\{\pm1\} x_i+b\big)\ge1,\quad y_i\big(w^\top \quad\text{s.t.}{\quad \frac12|w|^2 \min_{w,b}\
22	(1.22)	C x\in \forall \quad x a^\top \;\ge\; \alpha ;\<;\ z a^\top
22	(2.22)	t\in[0,1] C,\ x,y\in \forall f(x)+(1-t)f(y),\quad t f\big(tx+(1-t)y\big)\;\le\;
22	(3.22)	{\}ذلك f(x)=\{g:\text{يحقّق \partial y,\qquad \forall f(x)+g^\top(y-x)\quad f(y)\;\ge\;
22	(4.22)	محد… \text{ f } \;\;(\text{إن f^\star\star}=f \qquad f(x)\big\}, - x y^\top \sup_{x}\big\{ ;\=;\ f^\star(y)
22	(5.22)	y)-g^\star(y)\big\} d^\star=\max_y\big\{-f^\star(-A^\top p^\star=\min_x\big\{f(x)+g(Ax)\big\}\big\},\qquad
22	(6.22)	x_{k+1}=\mathrm{pr… g}(v)=\arg\min_x\Big\{g(x)+\frac{1}{2\gamma}|x-v|^2\Big\},\qquad \mathrm{prox}_{\gamma
22	(7.22)	y_{k}=x_{k}+\frac{t_{k-1}-1}{t_k}… f(y_{k-1})\big),\quad g\big(y_{k-1}-\eta\nabla x_{k}=\mathrm{prox}_{\eta
23	(1.23)	E|… \min_k\mathbb f(x_k),\qquad x_k]=\nabla g_k\mid E[\hat \mathbb g_k,\qquad x_{k+1}=x_k-\eta_k\,\hat
23	(2.23)	\beta\in0,1) x_{k+1}=x_k-\eta\,v_{k+1},\qquad f(x_k),\qquad v_{k+1}=\beta\,v_k+\nabla
23	(3.23)	f(y_k) x_{k+1}=y_k-\eta\,\nabla y_k=x_k+\beta\,(x_k-x_{k-1}),\qquad
23	(4.23)	g_k x_{k+1}=x_k-\frac{\eta}{\sqrt{G_k+\epsilon}}\odot g_t,\qquad g_t\odot G_k=\sum_{t=1}^k
23	(5.23)	x_{k+1}=x_k-\eta\,\frac{\… v_k=\beta_2v_{k-1}+(1-\beta_2)g_k^2,\quad m_k=\beta_1m_{k-1}+(1-\beta_1)g_k,\quad
23	(6.23)	… g_k]=\nabla E[\hat \mathbb x),\qquad f(\tilde x)+\nabla f_{i_k}(\tilde f_{i_k}(x_k)-\nabla g_k=\nabla \hat
23	(7.23)	…{التمام} k}{T}\Big)\quad\text{(جيب \eta_k=\eta_{\min}+\tfrac12(\eta_{\max}-\eta_{\min})\Big(1+\cos\frac{\pi
24	(1.24)	\text{اتّجا… M=\{\xi:\ T_x\mathcal f(x)\big),\qquad M{\big(\nabla\bar \mathrm{grad}\,f(x)\;=\;P_{T_x\mathcal
24	(2.24)	y}:T_x… T_{x\to \mathcal \mathrm{D}R_x(0)=\mathrm{id},\qquad R_x(0)=x,\quad x_{k+1}=R_{x_k}(\xi_k),\quad
24	(3.24)	\text{… \min_k|\mathrm{grad}f(x_k)|^2=O(1/K)\ x_{k+1}=R_{x_k}\big(-\eta_k\,\mathrm{grad}f(x_k)\big),\qquad
24	(4.24)	W\big(x,\xi,P^… f(x)[\xi]\Big)\;+\;\matfhrak M}\Big(\nabla^2\bar \mathrm{Hess}f(x)[\xi]\;=\;P_{T_x\mathcal
24	(5.24)	R_x(\xi)=\frac{x+\xi}{|x+\xi|} T_xS=\{\xi:x^\top\xi=0\},\qquad R^n:|x|=1\},\qquad S^{n-1}=\{x\in\mathbb
24	(6.24)	X^\top\xi+\xi^… T_X\mathrm{St}=\{\xi: X=I_p\},\qquad p{:X^\top R^{n\times \mathrm{St}(p,n)=\{X\in\mathbb
24	(7.24)	V\big\} V_p\perp U,\ U_p\perp r{,\ R^{r\times M\in\mathbb M_r=\big\{UMV^\top+U_pV^\top:\ T_X\mathcal
25	(1.25)	\{(x_t,f(x_t))\}_{t=1}^T } \text{الوصول: X}f(x),\qquad x^\star\in\arg\min_{x\in\mathcal
25	(2.25)	\sigma_t^2(x)=k(x,x)-k(x)^\top(K+\sigma_n^2I)^{-1}k(x) \mu_t(x)=m(x)+k(x)^\top(K+\sigma_n^2I)^{-1}(y-m),\qquad
25	(3.25)	=\big(f^\star_t-\mu_t(x)\big)\Phi(z)+… E\big[\max(0,\,f^\star_t-f(x))\big] \alpha_{\mathrm{EI}}(x)=\mathbb
25	(4.25)	\alpha_{\mathrm{PI}}(x)=\Phi\!\left(\frac{f^… \alpha_{\mathrm{UCB}}(x)=\mu_t(x)+\kappa_t\,\sigma_t(x),\qquad
25	(5.25)	T}) R_T=O(\sqrt{T\log } \text{يحقّق UCB R_T=\sum_{t=1}^T\big(f(x^\star)-f(x_t)\big),\qquad
25	(6.25)	AllReduce)} / بيانات \quad\text{(توازي x_{t+1}=x_t-\eta\,g g_k,\qquad g=\frac1K\sum_{k=1}^K
25	(7.25)	n_k n=\sum_k w_{t+1}=\sum_{k=1}^K\frac{n_k}{n}\,w_{t+1}^{(k)},\qquad

الجزء الخامس: نظرية المعلومات

الفصل	الوسم	الصيغة
26	(1.26)	E\!\left[\log\frac{1}{p(X)}\right] p(x)\;=\;\mathbb p(x)\,\log X} H(X)\;=\;-\sum_{x\in\mathcal
26	(2.26)	x) p(y\mid x)\log p(y\mid p(x)\sum_y X)=-\sum_x H(Y\mid p(x,y),\qquad H(X,Y)=-\sum_{x,y}p(x,y)\log
26	(3.26)	X)\;=\;\sum_{x,y}p(x,y)\log\frac{p(x,y)}{p(x)p(y)} Y)\;=\;H(Y)-H(Y\mid I(X;Y)\;=\;H(X)-H(X\mid
26	(4.26)	H(Y) X)\le H(Y\mid p,\qquad } \text{ مقعّرة في H X|,\qquad H(X)\le\log|\mathcal 0\le
26	(5.26)	e\,… N(\mu,\sigma^2))=\frac12\log\!\big(2\pi h(\mathcal f(x)\,dx,\qquad f(x)\log X} h(X)=-\int_{\mathcal
26	(6.26)	IG(Y;A) A^\star=\arg\max_A A)\;=\;I(Y;A),\qquad IG(Y;A)\;=\;H(Y)-H(Y\mid
26	(7.26)	p(x)\;\propto\;\… \;\Longrightarrow\; p=1 \sum E[f_i]=\alpha_i,\ \mathbb H(p)\quad\text{s.t.}{\quad \max_{p}\
27	(1.27)	q(x)\;=\;H(p)\,+\,D_{KL}(p\,|\,q) p(x)\,\log H(p,q)\;=\;-\sum_{x}
27	(2.27)	E_{p}\!\left\log\frac{p… p(x)\,\log\frac{p(x)}{q(x)}\;=\;\mathbb X} D_{KL}(p\,|\,q)\;=\;\sum_{x\in\mathcal
27	(3.27)	I(X;Y) I(X;Z)\le \Longrightarrow\ Z\ Y\to X\to \text{(جيبس)},\qquad \ D_{KL}(p\,|\,q)\;\ge\;0\
27	(4.27)	f(1)=0 محدّبة و } \text{ f \qquad f\!\left(\frac{p(x)}{q(x)}\right), q(x)\, D_f(p\,|\,q)\;=\;\sum_{x}
27	(5.27)	E_{q}[e^{T}]\Big) E_{p}[T]-\log\mathbb \Big(\mathbb D_{KL}(p|q)\;\ge\;\sup_{T}\,
27	(6.27)	e^{z_j}},… y_k=\frac{e^{z_k}}{\sum_j \hat y_k,\qquad \hat y_k\log L_{\text{CE}}\;=\;-\sum_{k=1}^{K} \mathcal
27	(7.27)	\mathrm{TV}=\tfrac12… m=\tfrac{p+q}{2},\qquad D_{KL}(q|m),\quad D_{KL}(p|m)+\tfrac12 D_{JS}(p|q)=\tfrac12

{ دائمًا ممكن \text{ H(X)+1 L<\ p(x)\,\ell(x)\;\ge\;H(X),\qquad L=\sum_x	(1.28)	28
{لكلّ استخدام للقناة) I(X;Y)\qquad\text{(بتّ C\;=\;\max_{p(x)}	(2.28)	28
L<H+1 H\le p_i\ell_i,\qquad L=\sum \min \log_2\frac{1}{p_i},\qquad \approx \ell_i	(3.28)	28
\text{الطول}\approx\log_2\frac{1}{p(x_1 ····· p(x_i),\qquad \prod_i \text{بحجم}\ \mathrm{lo}_n,\mathrm{hi}_n)\	(4.28)	28
D^{-\ell_i}\;\le\;1 \sum_i	(5.28)	28]
X) I(X;\hat D\ X)\le d(X,\hat E \mathbb x):\ x\mid R(D)=\min_{p(\hat	(6.28)	28
m)}_{… underbrace{\ell(D\mid\+{{النموذج D)=\underbrace{\ell(m)}_{\text{وصف L_{\text{total}}}(m, \mathcal	(7.28)	28
E_{p_\theta{\!\big\partial_i\ell(\theta;X)\,\partial_j\ell(\… g_{ij}(\theta)\;=\;I_{ij}(\theta)\;=\;\mathbb	(1.29)	29
I(\theta)\,d\theta d\theta^j\;=\;d\theta^\top ds^2\;=\;\sum_{i,j}g_{ij}(\theta)\,d\theta^i	(2.29)	29]
J_{ai}=\frac{\partial\theta^i}{\partial\phi^a} I(\theta)\,J,\qquad I(\phi)\;=\;J^\top	(3.29)	29
I(\theta)\,d\theta\;+\;… D_{\mathrm{KL}{\big(p_\theta\,|\,p_{\theta+d\theta}\big)\;=\;\frac12\,d\theta^\top	(4.29)	29
E\big[\nabla^2\ell\,\big] E\big[\nabla\ell\,\nabla\ell^\top\big]\;=\;-\,\mathbb I(\theta)\;=\;\mathbb	(5.29)	29
E_{p_\theta}\big[\nabla_\theta\ell(\theta;X)\big]\;=\;0 \mathbb	(6.29)	29
\mathrm{Var}_\theta(\hat\theta_i)\;\ge\;… \mathrm{Cov}_\theta(\hat\theta)\;\succeq\;I_n(\theta)^{-1},\qquad	(7.29)	29
\mathrm{Var}_\theta(\hat\theta)\;\ge\;\frac\big(1+b'(\theta)\big)^2{I_n(\theta)}	(8.29)	29
L L\;=\;I(\theta)^{-1}\,\nabla_\theta \tilde\nabla_\theta	(9.29)	29
L(\theta_t) \theta_{t+1}\;=\;\theta_t-\eta\,I(\theta_t)^{-1}\nabla_\theta	(10.29)	29
I(\theta)d\;\le\;\varepsilon d^\top \frac12 d\quad\text{s.t.}\quad L^\top \nabla \min_{d}\	(11.29)	29
L L\;=\;\nabla_\mu \tilde\nabla_\theta	(12.29)	29
… \theta\;=\;\nabla\varphi(\mu),\qquad E_{p_\theta{[T(X)]\;=\;\nabla\psi(\theta),\qquad \mu\;=\;\mathbb	(13.29)	29
I(\mu)^{-1}{\;=\;\nabla^2\varphi(\mu) I(\theta)\;=\;\nabla^2\psi(\theta),\qquad	(14.29)	29
D_{\mathrm{KL}{(p_\theta|p_{\theta'})\;=\;D_\psi(\theta'|\theta)\;=\;\psi(\theta')-\psi(\theta)-\nabla…	(15.29)	29
E\big[\partial_i\partial_j\ell\;\partial_k\ell\big]\;+\;\frac{1-\alpha}… \Gamma^{(\alpha)}_{ijk}\;=\;\mathbb	(16.29)	29
e{ \text{مستوٍ M\ p\in \forall p|p)\qquad p)\;+\;D(\hat D(q|p)\;=\;D(q|\hat	(17.29)	29
I(\gamma(t))\,\dot\gamma(t)… \int_0^1\sqrt{\dot\gamma(t)^\top d_F(p,q)\;=\;\inf_{\gamma(0)=p,\,\gamma(1)=q}\	(18.29)	29
c>0 I,\ c\cdot أيّ{\text متر ريماني ثابت تحت تطبيقات ماركوف الإحصائية هو }	(19.29)	29
q\big|\;=\;2\arccos\!\big(\sqrt{pq}+… p-\arcsin\sqrt d_F(p,q)\;=\;2\big|\arcsin\sqrt \text{برنولي:}\quad	(20.29)	29
d_F=\sqrt2\,\cosh^{-1}{!\!\left(\… ds^2=\frac{d\mu^2+2\,d\sigma^2}{\sigma^2},\qquad quad\ غاوسي:}{أحادي \text	(21.29)	29
d_F(\mu_1,\mu_2)=\sqrt{(\mu_1-\mu_2)^\top\Sigma^{-1}(\mu_1-…· quad\}{ ثابت:} \Sigma\text غاوسي}{متعدّد بـ \text	(22.29)	29
L(q,\theta)}\;+\… p(x,z;\theta)\big]+H(q)_{\mathcal E_{q}\big[\log p(x;\theta)\;=\;\underbrace{\mathbb \log	(23.29)	29
x;\theta_t)\big)=p(… D_{\mathrm{KL}{\big(q\,|\,p(z\mid q_{t+1}\;=\;\arg\min_q e):{\quad إسقاط) \text{E-step	(24.29)	29
p(x,z;\theta)\big] E_{q_{t+1}}\big[\log \mathbb \theta_{t+1}\;=\;\arg\max_\theta m):{\quad إسقاط) \text{M-step	(25.29)	29
F_\ell^{-1}… E[gg^\top],\qquad G=\mathbb E[aa^\top],\quad A=\mathbb G,\qquad F_\ell\;\approx\;A\otimes	(26.29)	29
F_{ii}\,\big(\theta_i-\theta_i^\star\big)^2… L(\theta)=L(\theta)+\frac{\mu}{2}\sum_i \tilde \text{EWC:}\quad	(27.29)	29

الجزء السادس: نظرية التعلّم الإحصائي

الصيغة	الوسم	الفصل
D}\big[\ell(h(x),y)\big] E_{(x,y)\sim\mathcal R(h)\;=\;\mathbb	(1.30)	30
R_S(h)\;=\;\frac1n\sum_{i=1}^n\ell\big(h(x_i),y_i\big) \hat	(2.30)	30
R_S(h) H}\hat h_{\mathrm{ERM}{\;\in\;\arg\min_{h\in\mathcal \hat	(3.30)	30
(بليز) \text{مصنّف} \ R(h)\ h^\star=\arg\min R(h),\qqquad{للقياس \text{قابلة R^\star\;=\;\inf_{h\	(4.30)	30
estimat… التقدير H}R(h)\Big)_{\text{خطأ h)-\inf_{h\in\mathcal h)-R^\star\;=\;\underbrace{\Big(R(\hat R(\hat	(5.30)	30
H|… H|,\delta)\;=\;\sqrt{\frac{\ln!\!\big(2|\mathcal R_S(h)\big|\;\le\;\varepsilon(n,|\mathcal \big|R(h)-\hat	(6.30)	30
H|/\delta\big){2n}} h)\;+\;\sqrt{\frac{\ln\!\big(2|\mathcal R_S(\hat h)\;\le\;\hat R(\hat	(7.30)	30
… H_k,n,\delta)\Big],\qquad R_S(h)\;+\;\Omega(\mathcal H_k}\hat k\;=\;\arg\min_k\Big[\min_{h\in\mathcal \hat	(8.30)	30
h(x)-f(x)\big)^2}_{\mathrm{Bias}^2}… E_S\Big[\big(h_S(x)-f(x)\big)^2\Big]\;=\;\underbrace{\big(\bar \mathbb	(9.30)	30
E_S\big[h_S(x)\big] h(x)\;=\;\mathbb \bar	(10.30)	30
\lambda>0 R_S(h)\;+\;\lambda\,\Omega(h),\qquad \hat H}\ \min_{h\in\mathcal	(11.30)	30
y I)^{-1}X^\top X+\lambda w_{\text{ridge}}\;=\;(X^\top \hat	(12.30)	30
متع… \text{بتصميم \quad\Rightarrow\quad w_{\text{lasso}}\;=\;\arg\min_w\frac1n|y-Xw|^2+\lambda|w|_1 \hat	(13.30)	30
w_\lambda)=\frac{… \mathrm{Bias}^2(\hat s}{(s+\lambda)^2},\qquad w_\lambda)=\frac{\sigma^2 \mathrm{Var}(\hat	(14.30)	30
R_V(h)\big|\;\le\;\sqrt{\frac{\ln(2/\delta)}{2m}} \big|R(h)-\hat	(15.30)	30
R_V(h)\big|\;\le\;\sqrt{\frac{\ln(2K/\delta)}{2m}} \big|R(h)-\hat h\in\{h_1,\dots,h_K\}:\quad \forall	(16.30)	30
S=\bigsqcup_{j=1}^… R_{S_j}\big(A(S_{-j})\big),\qquad R_{\mathrm{CV}}\;=\;\frac1k\sum_{j=1}^{k}\hat \widehat	(17.30)	30
R_S(h)\big| H}\big|R(h)-\hat h)\;\le\;\sup_{h\in\mathcal R_S(\hat h)-\hat R(\hat	(18.30)	30
…{ توزيع H}R(h)\qquad\text{لكلّ E_S\big[R(A(S))\big]\;\xrightarrow[n\to\infty]{}\;\inf_{h\in\mathcal \mathbb	(19.30)	30
F|}\sum_{f\in… F}R_f\big(A(S_f)\big)\;=\;\frac1{|\mathcal F|}\sum_{f\in\mathcal \frac1{|\mathcal	(20.30)	30
approximation}{… H}R(h)-R^\star\Big)_{\text{تقريب h)-R^\star\;=\;\underbrace{\Big(\inf_{h\in\mathcal R(\hat	(21.30)	30
n… \text{ب}\ \text{تقدير}\downarrow\ \quad;\quad أوسع} H\text{ \mathcal \text{ب}\ \text{تقريب}\downarrow\	(22.30)	30
H\big\{\;\subseteq\;\{-1+,1\}^m h\in\mathcal H|_S\;=\;\big\{(h(x_1),\dots,h(x_m)):\ \mathcal	(1.31)	31
{S\big\} تحطم H\text{ \mathcal |S|=m,\ S,\ \exists H)\;=\;\max\big\{m:\ d_{\mathrm{VC}}(\mathcal	(2.31)	31
H|_S\big| H}(m)\;=\;\max_{S:|S|=m}\big|\mathcal \Pi_{\mathcal	(3.31)	31
d) (m\ge H}(m)\;\le\;\sum_{i=0}^{d}\binom{m}{i}\;\le\;\Big(\frac{em}{d}\Big)^d\qquad \Pi_{\mathcal	(4.31)	31

H\{(2n)\}{\delta}\} R_S(h)\;+\;\sqrt\{\frac{8}{n}\,\ln\frac{4\,\Pi_{\mathcal R(h)\;Ie\;\hat (5.31) 31
R_S(h)\;+\;\sqrt\{\frac{8}{n}\left(d\,\ln\frac{2en}{d}\;+\;\ln\frac4\delta\right)} R(h)\;Ie\;\hat (6.31) 31
n\;=\;O\!\left(\frac{d+\ln(1/\delta)}{\varepsilon^2}\right) (7.31) 31
F\{\frac1n\sum_{i=1}^{n}... E_{\sigma}\Bigg\sup_{f\in\mathcal F)\;=\;\mathbb R}_S(\mathcal \hat{\matfhrak (8.31) 31
F)\;+\;3\sqrt\{\frac{\ln(2/\delta)}{2n}} R}_S(\mathcal R_S(f)\;+\;2\,\hat{\matfhrak R(f)\;le\;\hat (9.31) 31]
F\|{n}} F)\;le\;\sqrt\{\frac{2\ln\|\mathcal R}_S(\mathcal \hat{\matfhrak (10.31) 31
B\{\big)\;le\;\frac{B}{n}\sqrt{\sum_{i=1}^{n}\|x_... \|w\|_2\le x:\ w^\top R}_S\big(\{x\mapsto \hat{\matfhrak (11.31) 31
f\in... \forall f_1,\dots,f_N,\ \exists F,\|\cdot\|)\;=\;\min\Big\{N:\ N(\varepsilon,\mathcal \mathcal (12.31) 31
N=d... \ln\mathcal N(\varepsilon,B_2^d},\|\cdot\|_2)\;le\;\Big(\frac3\varepsilon\Big)^d},\qquad \mathcal (13.31) 31
n}\int_{\alpha}^... F)\;le\;\inf_{\alpha\ge0}\Bigg\{4\alpha\;+\;\frac{12}{\sqrt R}_S(\mathcal \hat{\matfhrak (14.31) 31
d\;=\;17.2\sqrt{\frac{d}{n}} sqrt\,\43.1 n}\cdot F)\;\approx\;\frac{12}{\sqrt R}_S(\mathcal \hat{\matfhrak (15.31) 31
1-\tfrac{y\,h(x)}{\gamma}\big)\Big) \max\big(0,\ \ell_\gamma\big(h,(x,y)\big)\;=\;\min\Big(1,\ (16.31) 31
n}\;+\;3\sqrt{\frac{\ln(2/\delta)}{2n}} R_\gamma(h)\;+\;\frac{2\,B\,R_x}{\gamma\sqrt R(h)\;Ie\;\hat (17.31) 31
n}\;+\;3\sqrt{\frac{\ln(2/... R_\gamma(h)\;+\;\frac{2\sqrt\kappa}{\lambda\,\gamma\,\sqrt R(h)\;Ie\;\hat (18.31) 31
W L\log L\log\!\big(\tfrac{W}{L}\big)\;Ie\;d_{\mathrm{VC}}\;le\;C\,W c\,W (19.31) 31
{قطعة 2^L}\text{ \Rightarrow L تلغارسكي: عرض 2 وعمق }\text{وبناء #\text{pieces}}\;Ie\;(n+1)^L},\qquad (20.31) 31
n}\;\prod_{l=1}^{L}\|W_l\|_{... F_{\text{net}})\;\lesssim\;\frac{\|X\|_F}{\sqrt R}_S(\mathcal \hat{\matfhrak (21.31) 31
D\{\big(A(S)\big)\;le\;\varepsilon\,\Big]\;\ge\;1-\delta D^n}}\Big[\,R_{\mathcal P_{S\sim\mathcal \mathbb (1.32) 32
H\{R(h)+\varepsilon\,\Big]\;\ge\;1-\delta P\Big[\,R\big(A(S)\big)\;le\;\inf_{h\in\mathcal \mathbb (2.32) 32
d_{\mathrm{VC}}{(... \quad\Longleftrightarrow\quad ERM)} بخوارزمية PAC قابلة للتعلّم بـ \text{ H \mathcal (3.32) 32
H\{(\varepsilon,\delta)\;=\;O\!\left(\frac{d\,\ln(1/\varepsilon)+\ln(1/\delta)}{\varepsilon}\right) m_{\mathcal (4.32) 32
n\;\ge\;\frac{8\,d\,\ln(13/\varepsilon)+4\ln(4/\delta)}{\varepsilon} quad\}:العبارة \text{وبصريح (5.32) 32
H\{(\varepsilon,\delta)\;=\;\Theta\!\left(\frac{d+\ln(1/\delta)}{\varepsilon^2}\right) m_{\mathcal (6.32) 32
n\;\ge\;\frac{C\big(d+\ln(1/... H\{R(h)\;+\;\varepsilon,\qquad h\big)\;le\;\inf_{h\in\mathcal R\big(\hat (7.32) 32
n\;\ge\;\frac{8}{\varepsilon^2}{\Big(2d+\ln\frac{4}{}... quad\}:(من مبرهنة التأسيس) العبارة \text{وبصريح (8.32) 32
H\{(\varepsilon,\delta)\;\ge\;\frac{d-1}{32\,\varepsilon} m_{\mathcal (9.32) 32
H\{(\varepsilon,\delta)\;=\;\Omega\!\left(\frac{d}{\varepsilon^2}\right) m_{\mathcal (10.32) 32
n_{\text{غير متح... n_{\text{تحقّقي}}}\;\approx\;\frac{d\,\ln(1/\varepsilon)+\ln(1/\delta)}{\varepsilon},\qquad (11.32) 32
\begin{array}{c\|c} \text{الفئة} & \text{عتبات على} \\\hline d_{\mathrm{VC}} & \mathbb R \\ 1 & \text{فترات على... (12.32) 32
(2T\gamma^2\big-)le\;\exp\!\big\;|\text{التدريب} \text{خطأ (13.32) 32
T\;\ge\;\frac{\ln(1/\varepsilon)}{2\gamma^2}} (14.32) 32
{(حسابياً) التعلّم \text{قابلية} \;\not\Rightarrow\; (إحصائياً) التعلّم \text{قابلية} (15.32) 32
\sup_{S,\i,\;z}\;\sup_{z'}\Big\|\;\ell\big(A(S),z'\big)\;-\;\ell\big(A(S^{i,z}),z'\big)\;\Big\|\;Ie\;\beta (1.33) 33
R_S\big(A(S)\big)\;+\;2\beta\;+\;\big(4n\beta+M\big)\sqrt{\frac{\ln(1/\delta)}{2n}} R\big(A(S)\big)\;Ie\;\hat (2.33) 33
R_S(A(S))\big]\;\Big\|\;le\;\beta E_S\big[\hat E_S\big[R(A(S))\big]-\mathbb \Big\|\;\mathbb (3.33) 33
F_S(w)\;=\;\frac1n\sum_{i=1}^n\ell(w,z_i)\;+\;\frac\lambda2\|w\|^2 A(S)\;=\;\arg\min_{w}\;F_S(w),\qquad (4.33) 33
n} \big\|A(S)-A(S^{i,z})\big\|\;le\;\frac{2L}{\lambda (5.33) 33
n} \beta\;le\;\frac{2L^2}{\lambda (6.33) 33
n}\;+\;\Big(\frac{8L^2}{\lambda}+M... R_S\big(A(S)\big)\;+\;\frac{4L^2}{\lambda R\big(A(S)\big)\;Ie\;\hat (7.33) 33
\lambda\;\ge\;\frac{2L^2}{\beta\,n} (8.33) 33
t=1,\dots,T W}\Big(w_t-\alpha_t\,\nabla_w\ell\big(w_t;z_{i_t}\big)\Big),\qquad w_{t+1}\;=\;\Pi_{\mathcal (9.33) 33
\big\|\nabla\ell(w;z)-\nabla\ell(w';z)\big\|\... qquad\}(الخسارة L\quad\text{لبشيتزية \|\nabla\ell(w;z)\|\le (10.33) 33
\beta\;le\;\frac{2L^2}{n}\sum_{t=1}^{T}\alpha_t (11.33) 33
R_S(A(S))\;+\;\frac{4L^2}{n}\sum_{t=1}^T\alpha_t\;+\;\Big(8L^2\sum_{t=1}^T\alpha_t+M... R(A(S))\;Ie\;\hat (12.33) 33
\beta\;le\;\frac{2L^2}{n\gamma}\Big[\big(1+\alpha\gamma\big)^{T}-1\Big] \text{ثابت:}\qquad \alpha_t=\alpha\ (13.33) 33
\beta\;le\;\frac{2L^2}{n\gamma}\Big[T^{\,c\gamma}-1\Big] \text{متضائل:}\qquad ct\ \alpha_t=\frac (14.33) 33
E[\delta_t]\;+\;\frac{2\alpha_tL}{n} E[\delta_{t+1}]\;le\;(1+\alpha_t\gamma)\,\mathbb \mathbb (15.33) 33
R_{\mathrm{LOO}}\;=\;\frac1n\sum_{i=1}^n\ell\Big(A(S^{-i}),\,z_i\Big) \widehat (16.33) 33
z \big\|\ell(A(S),z)-\ell(A(S^{-i}),z)\big\|\;le\;\beta_e\quad\forall qquad\}:الخطأ \text{استقرار (17.33) 33
E_z\Big[\big\|\ell(A(S),z)-\ell(A(S^{-i}),z)\big\|\Big]\;le\;\beta_h \mathbb qquad\}:الفرضية \text{استقرار (18.33) 33
E\big[R\big(A(S^{-1})\big)\big)\big] R_{\mathrm{LOO}}\big]\;=\;\mathbb E_S\big[\widehat \mathbb (19.33) 33
R_{\mathrm{LOO}}-R\big(A(S)\big)\Big\|\;le\;\beta_e\;+\;\big(n\beta_e+M\big)\sqrt{\frac{\ln(1... \Big\|\widehat (20.33) 33
R\big(n(1-\tfrac1k)\big)-R(n)\;=\;a\Big(\frac{1}{n(1-1/k)}-\frac1n\Big)\;=\;\frac{a}{n(k-1)} (21.33) 33
n}\;+\;\Big(\frac{2L^2}{}... R_{\mathrm{LOO}}-R\big(A(S)\big)\Big\|\;le\;\frac{2L^2}{\lambda \Big\|\widehat (22.33) 33
s}-1} T \lambda_{\mathrm{eff}}(s)\;=\;\frac{s}{e^}\alpha (23.33) 33
w_m)\;\approx\;\min\Big(1,\;\frac{2\tau}{m}\Big)\,\mathrm{Var}(w_t) \mathrm{Var}(\bar (24.33) 33
E\big[\|\Delta_t\|^2\big]\;le\;\frac{4\alpha_t^2L^2}{n\,b} \mathbb (25.33) 33
\beta\;le\;\frac{2L^2}{n}\cdot\frac1{1-\mu}\sum_{t=1}^T\alpha_t (26.33) 33
\sum_t\alpha_t'\;=\;\big(\kappa\alpha\big)\Big(\frac{T}{\kappa}\Big)\;=\;\sum_t\alpha_t (27.33) 33
\underbrace{2\beta(... }_{T)}\qquad\text{و}\qquad (ينقص مع \underbrace{R\big(A(S)\big)-\inf_{w}R(w)}_{\text{تحيز} (28.33) 33
O\big]\;+\;\delta_{\mathrm{DP}} O\big]\;le\;e^{\varepsilon}\Pr\big[A(S')\in\mathcal \Pr\big[A(S)\in\mathcal (29.33) 33
R_S(A(S))\big]\;\Big\|\;le\;e^{\varepsilon-1}\;+\;... E\big[\hat E\big[R(A(S))\big]-\mathbb \Big\|\;\mathbb (30.33) 33
R\Big\|\;le\;\big(e^{\varepsilon}-1+\delta_{\mathrm{DP}}\big)\;+\;O\!\left(\sqrt{\frac{\ln(1/... \Big\|R-\hat (31.33) 33
N... B{\mathrm{clip}_C\big(\nabla\ell(w;z_i)\big)\;+\;\mathcal g\;=\;\frac1b\Big(\sum_{i\in\mathcal \tilde (32.33) 33
bn q=\frac \varepsilon\;\approx\;\frac{q\sqrt{T\ln(1/\delta_{\mathrm{DP}})}}}{\sigma}\qquad (33.33) 33
\mathrm{TPR}\;le\;e^{\varepsilon}\,\mathrm{FPR}\;+\;\delta_{\mathrm{DP}} (34.33) 33
\varepsilon_{\mathrm{tot}}\;=\;\sqrt{2k\ln(1/\delta_{\mathrm{DP}})}\,\varepsilon+k\varepsilon\big(e^{... (35.33) 33
\beta\;le\;\frac{2C^2}{n}\sum_t\alpha_t... qquad\}(قوي n}\quad\text{تنظيم \beta\;le\;\frac{2C^2}{\lambda (36.33) 33

\... H)\;+\;3\sqrt{\frac{\ln(2/\delta)}{2n}},\qquad R_n(\mathcal R_S(h)\;+\;2\,\matfhrak R(h)\;\Ie\;\hat	(37.33)	33
O\!\left(\frac{\prod_{i}|W_i|_{\mathrm{op}}}\sqrt{L_{\text{طبقات}}}\... R_\gamma(h)\;+\;\tilde R(h)\;\Ie\;\hat	(38.33)	33
}(14.33) \beta\;\le\;\frac{2L^2}{n}\sum_{t=1}^T\alpha_t\;+\;\text{حدود غير محدّبة من	(39.33)	33
L\;=\;\sup_{z}\big|\nabla_w\ell(w;z)\big|\;\le\;|x|\cdot\prod_{i=1}^{L_{\text{طبقات}}}|W_i|_{\mathrm{\...	(40.33)	33
\quad\text{على R\approx \qquad}، تسميات عشوائيّة R_S=0\quad\text{على \hat 1-\tfrac1K الاختبار}	(41.33)	33
R_S(h)=0\... \hat \} اختيار للمعلمات يحقّق \text{يوجد Y|\qquad\Longrightarrow\qquad p\,b\;\ge\;n\log_2|\mathcal	(1.34)	34
H}{2n}}{\... h)\;+\;\underbrace{\sqrt{\frac{8}{n}\,\ln\!\frac{4\,\Pi_{\mathcal R_S(\hat h)\;\Ie\;\hat R(\hat	(2.34)	34
2\;+\;\frac{8}{n}\ln\frac{4}{\delta}\,\;\approx\;3.1;\<;\33 \Omega_{VC}\;=\;\sqrt{\,16\ln	(3.34)	34
H)\;+\;3\sqrt{\frac{\ln(2/\... R}_n(\ell\circ\mathcal h)\;+\;2\,\hat{\matfhrak R_S(\hat h)\;\le\;\hat R(\hat	(4.34)	34
1\big\... R_\gamma(h)\;=\;\frac1n\sum_{i=1}^n\mathfb \hat y_i{f(x_i)_j,\qquad m_i\;=\;f(x_i)_{y_i}-\max_{j\neq	(5.34)	34
O\!\left(\frac{|X|_F\,\prod_{l=1}^{L}|W_l|_\sigma}{\gamma\,\... R_\gamma(h)\;+\;\tilde R(h)\;\le\;\hat	(6.34)	34]
n}\Big(\prod_{l=1}^{L}\... O\!\left(\frac{|X|_F\,\ln(d_0)}{\gamma\sqrt R_\gamma(h)\;+\;\tilde R(h)\;\Ie\;\hat	(7.34)	34
O\!\left(\frac{L^3/2}{\gamma}\;\prod_{l=1}^{L}|W_l|_\sigma\right) R_\gamma(h)\;+\;\tilde R(h)\;\le\;\hat	(8.34)	34
R_S(h)\big] Q{\big[\hat E_{h\sim R_S(Q)\;=\;\mathbb \hat Q{\big[R(h)\big],\qquad E_{h\sim R(Q)\;=\;\mathbb	(9.34)	34
R_S(Q)\;+\;\sqrt{\frac{\mathrm{KL}(Q|P)+\ln\!\big(2n/\delta\big)}{2n}} R(Q)\;\le\;\hat	(10.34)	34
R_S(Q)\,|\,R(Q)\big)\;\le\;\frac{\mathrm{KL}(Q|P)+\ln\!\big((n+1)/\delta\big)}{n},\... \mathrm{kl}\big(\hat	(11.34)	34
\mathrm{KL}(Q|P)\;=\;\frac{|w|_2^2}{2\sigma^2}	(12.34)	34
\sqrt{\frac{500+\ln(2\times10^6)}{10^5}}\;=\;\sqrt{\frac{514.51}{5^10}}\;=\;1;\>;\0717.0	(13.34)	34
n}{n}}\right) O\!\left(\sqrt{\frac{k}{\ln h)\;+\;\gamma\;+\;\tilde R_S(\hat h)\;\le\;\hat R(\hat	(14.34)	34
\ln\binom{p}{k}\;\le\;k\ln\frac{e\,p}{k}	(15.34)	34
2+\ln(2/\delta)}{2n}} \varepsilon_{\mathrm{quant}}\;=\;\sqrt{\frac{k\,b\,\ln	(16.34)	34
.../ln(1\+{الوصف بالنت O\!\left(\sqrt{\frac{\text{طول h)\;+\;\gamma\;+\;\tilde R_S(\hat h)\;\le\;\hat R(\hat	(17.34)	34
y_i\,w^\... \min_{i}\ \{1 \frac{w_t}{|w_t|_2}\;\longrightarrow\;w_{\mathrm{SVM}}\;=\;\arg\max_{|w|_2\le	(18.34)	34
t}\right) \gamma^\star-\gamma_t\;=\;O\!\left(\frac{1}{\log t),\qquad |w_t|_2\;=\;\Theta(\log	(19.34)	34
x_i y_i\,w^\top \min_i\ \{1 \frac{w_t}{|w_t|_\infty}\;\longrightarrow\;\arg\max_{|w|_\infty\le	(20.34)	34
\lambda_{\mathrm{مكافئ}}\;\approx\;\frac{2}{\eta\,t}	(21.34)	34
\... كبر } \text{كلّما \bar\gamma\;=\;\frac{\gamma}{\prod_{l=1}^{L}|W_l|_\sigma}\qquad\Longrightarrow\qquad	(22.34)	34
ا...n}_{\text{نقطة \underbrace{p\approx \qquad} p خطر يهبط مع \text{معلّم}}\;:\}\underbrace{p<n}_{\text{تحت	(23.34)	34
R_k(\Sigma)\;=\;\frac{\big(\sum_{i>k}\... r_k(\Sigma)\;=\;\frac{\sum_{i>k}\lambda_i}{\lambda_{k+1}},\qquad	(24.34)	34
\frac{n}{R_k(\Sigma)}\;\to\;0 (b>1),\qquad \ r_k(\Sigma)\;\ge\;b\,n\ \frac{k}{n}\to0,\qquad	(25.34)	34
R\big(\hat\theta\big)\;\lesssim\;\underbrace{|\theta^\star|^2\,\lambda_{k+1}}_{\text{انحياز}}\;+\;\...	(26.34)	34
Y|\} R(\hat\theta)\;\longrightarrow\;1-\frac{1}{|\mathcal R_S(\hat\theta)=0,\qquad \hat	(27.34)	34
f(x';\theta)\big\rangle \nabla_\theta f(x;\theta),\, \nabla_\theta \Theta(x,x')\;=\;\big\langle	(28.34)	34
f^\top,\frac{d\theta}{dt}\... \frac{df_t}{dt}\;=\;-\nabla_\theta L,\qquad \frac{d\theta}{dt}\;=\;-\nabla_\theta	(29.34)	34
t_\varepsilon\;\approx\;\frac{\ln(1/\varepsilon)}{\lambda_{\min}(\... f_t-y\;=\;e^{-\Theta\,t}\,(f_0-y),\qquad	(30.34)	34
1 |I\ m}\right)\ \frac{|\theta_t-\theta_0|}{|\theta_0|}\;=\;O\!\left(\frac{1}{\sqrt	(31.34)	34
O\!\left(\sqrt{\frac{2\;y^\top\Theta^{-1}y}{n}}\right) R\;\le\;\tilde	(32.34)	34
\eta\;\le\;\frac{2}{\lambda_{\max}(\Theta)}	(33.34)	34

الجزء السابع: رياضيات الشبكات العصبية

الفصل	الوسم	الصيغة
35	(1.35)	y_i\,x_i + w\;\leftarrow\;w
35	(2.35)	R |x_i|\le i,\qquad x_i\big)\;\ge\;\gamma>0\quad\forall y_i\big(w^{\star\top}
35	(3.35)	T\;\le\;\Big\lceil\Big(\frac{R}{\gamma}\Big)^2\Big\rceil
35	(1)	T\gamma \;\ge\; w^\star y_i\,x_i^\top \sum = w^\star w_T^\top
35	(2)	\sqrt{T}\,R |w_T|\le \quad\Rightarrow\quad T\,R^2 \;\le\; R^2 + |w_{T-1}|^2 \;\le\; |w_T|^2
35	(3)	\quad\Rightarrow... R \sqrt{T}\,\gamma\le \quad\Rightarrow\quad \sqrt{T}\,R \;\le\; |w_T| \;\le\; T\gamma
35	(4.35)	\sigma^{(\ell)}\big(z^{(\ell)}\big),\... = a^{(\ell)} b^{(\ell)},\qquad + a^{(\ell-1)} W^{(\ell)} = z^{(\ell)}
35	(5.35)	\theta=\big\{W^{(\ell)},b^{(\ell)}\big\}_{\ell=1}^L f(x;\theta)=a^{(L)},\qquad
35	(6.35)	d_{\ell-1}+d_\ell\big) N_{\mathrm{param}}=\sum_{\ell=1}^L\big(d_\ell
35	(7.35)	\sigma_{\mathrm{sig}}'(t)=\sigma_{\mathrm{sig}}(t)\big(1... \sigma_{\mathrm{sig}}(t)=\frac{1}{1+e^{-t}},\qquad
35	(8.35)	\tanh'(t)=1-\tanh^2(t) \tanh(t)=\frac{e^t-e^{-t}}{e^t+e^{-t}},\qquad
35	(9.35)	1_{t>0} \mathrm{ReLU}'(t)=\mathfb \mathrm{ReLU}(t)=\max(0,t),\qquad
35	(10.35)	w_j\in... R,\ x+b_j\big)\;:\;c_j\in\mathbb c_j\,\sigma\big(w_j^\top F_m=\Big\{\,g(x)=\sum_{j=1}^m \mathcal
35	(11.35)	\sup_{x... N):\quad (m\in\mathbb F_m\ g\in\mathcal \exists \forall\varepsilon>0,\ K),\ C(\mathcal f\in \forall
35	(12.35)	\int_{... }n+1:\quad بعرض ReLU شبكة \exists\text{ \forall\varepsilon>0,\ L^1_{\mathrm{loc}},\ f\in \forall
35	(13.35)	\infty > f(\omega)|\,d\omega R^d|\omega|\,|\hat B_2(f)=\int_{\mathbb
35	(14.35)	\frac{C\,B_2(f)}{\sqrt{m}} \;\le\; |f-g|_{L^2(\mu)}
35	(15.35)	d)^L\big) O\big((W\cdot quad\{\text{على الأكثر \quad\Omega\big(W^{L}\big)
35	(16.35)	W_{\mathrm{shallow}}\;\ge\;2^\Omega(L/d)
36	(1.36)	v_i\{ v_j}{\partial v_j\,\frac{\partial \bar v_i\in\mathrm{inputs}(v_j)} \sum_{j:\ ;\=;\ v_i \bar
36	(2.36)	\delta^{(\ell)}\,\big(a^{(\ell-1)}\big)^\top = W^{(\ell)}\{\partial \frac{\partial
36	(3.36)	\delta^{(\ell)} \big(W^{(\ell)}\big)^\top = a^{(\ell-1)}\{\partial \frac{\partial
36	(4.36)	\delta^{(\ell)} = b^{(\ell)}\{\partial \frac{\partial
36	(5.36)	\sigma'\big(z^{(\ell-1)}\big) \;\odot\; \delta^{(\ell)} \big(W^{(\ell)}\big)^\top = \delta^{(\ell-1)}

{الأوليّة \text{للعمليات C\in[2,4]\ C\cdot\mathrm{cost}(f),\qquad f)\;\le\; \mathrm{cost}(\nabla	(8.36)	36
y_i - y_i \hat = z_i} L{{\partial \frac{\partial	(9.36)	36
\delta^{(L)} \big(W^{(L)}\big)^\top\cdots\big(W^{(2)}\big)^\top = \delta^{(1)}	(10.36)	36
f'(x)\;\approx\;\frac{f(x+h)-f(x-h)}{2h}	(11.36)	36
\frac{|g_{\mathrm{num}}-g_{\mathrm{auto}}|}{|g_{\mathrm{num}}|+|g_{\mathrm{auto}}|+10^{-12}} = r	(12.36)	36
X(i+m,j+n,c_{in})\,K(m,n,c_{in},c_{out}) Y(i,j,c_{out})=\sum_{c_{in}}\sum_{m,n}	(1.37)	37
1 + \left\flloor\frac{W-k+2P}{S}\right\rfloor = O	(2.37)	37
k^2\,C_{in}\,C_{out}+C_{out} = N_{\mathrm{param}}	(3.37)	37
L(f) f)=T_x L(T_x	(4.37)	37
.من الخطوة multiple بض الإزاحة \quad\text{عند f)=P(f) P(T_x	(5.37)	37
\quad\text{(أقصى)} X_p(i\,s_p+m,j\,s_p+n) Y_p(i,j)=\max_{m,n<k_p}	(6.37)	37
O_p=\left\flloor\frac{O-k_p}{s_p}\right\rfloor+1	(7.37)	37
RF_0=1 \qquad s_i, (k_l-1)\prod_{i<l} + RF_{l-1} = RF_l	(8.37)	37
...على \quad(\text{مجموع Y}\,X_{\mathrm{col}}^\top L{{\partial \frac{\partial W}= L{{\partial \frac{\partial	(9.37)	37
N_{\mathrm{sep}}=k^2{C_{in}+C_{in}C_{out}	(10.37)	37
N_{\mathrm{group}}=\frac{k^2{C_{in}C_{out}}{g}	(11.37)	37
h_t+b_y) y_t=\mathrm{softmax}(W_y x_t+b\big),\qquad h_{t-1}+W_x h_t=\tanh\!\big(W_h	(1.38)	38
d_h+d_y d_x+d_h+d_y N_{\mathrm{RNN}}=d_h^2+d_h	(2.38)	38
2}\big)\,W_h\Big) h_k}=\prod_{j=k}^{t-1}\Big(\mathrm{diag}\big(1-h_{j+1}^\odot h_t}{\partial \frac{\partial	(3.38)	38
\rho(W_h)^\,t-1} h_1\right|\approx h_t}{\partial \left|\frac{\partial	(4.38)	38
g_t&=\tanh(W_gh_... i_t&=\sigma(W_i[h_{t-1},x_t]+b_i),\\ & f_t&=\sigma(W_f[h_{t-1},x_t]+b_f), \begin{aligned}	(5.38)	38
N_{\mathrm{LSTM}}=4\big(d_h(d_h+d_x)+d_h\big)	(6.38)	38]
h_t&=... \tilde z_t&=\sigma(W_z[h_{t-1},x_t]+b_z),\\ & r_t&=\sigma(W_r[h_{t-1},x_t]+b_r), \begin{aligned}	(7.38)	38
N_{\mathrm{GRU}}=3\big(d_h(d_h+d_x)+d_h\big)	(8.38)	38
h_t') y_t\sim\mathrm{softmax}(W_o c\big),\qquad y_{t-1}+U h_{t-1}'+W_y h_t'=\tanh\!\big(W_h	(9.38)	38
E[i,:] = e_i	(10.38)	38
d_x) C_{\mathrm{step}}=O(d_h^2+d_h	(11.38)	38
\mathrm{Attention}(Q,K,V)=\mathrm{softmax}\!\left(\frac{QK^\top}{\sqrt{d_k}}\right)V	(1.39)	39
\mathrm{head}_i=\mathrm{Attention}(QW_i^Q,KW_i^K,VW_i^V)	(2.39)	39
N_{\mathrm{MHA}}=4\,d_{model}^2	(3.39)	39
PE_{(pos,2i+1)}=\cos\!\left(\frac{... PE_{(pos,2i)}=\sin\!\left(\frac{pos}{10000^{2i/d_{model}}}\right),\qquad	(4.39)	39
R^... W_2\in\mathbb d_{ff}},\ R^{d_{model}\times W_1\in\mathbb \qquad \mathrm{FFN}(x)=\max(0,xW_1+b_1)W_2+b_2,	(5.39)	39
N_{\mathrm{FFN}}=2\,d_{model}\,d_{ff}+d_{ff}+d_{model}=8d_{model}^2+5d_{model}	(6.39)	39
C_{\mathrm{attn}}=O(n^2d)	(7.39)	39
\text{محظور}\end{cases} & -\infty \text{مسموح}\\ & k_j}\sqrt{d_k}} A_{ij}=\begin{cases}\frac{q_i\cdot	(8.39)	39
V=H_{\mathrm{enc}}W^V K=H_{\mathrm{enc}}W^K,\qquad Q=H_{\mathrm{dec}}W^Q,\qquad	(9.39)	39
... f(x';\theta)\Big\rangle_{\mathbb \nabla_\theta f(x;\theta),\ \nabla_\theta \Theta(x,x';\theta)=\Big\langle	(1.40)	40
E_{\theta}\big[\Theta(x,x';\theta)\big] \Theta(x,x')=\mathbb	(2.40)	40
\frac{d}{dt}f(x_i;t)=-\sum_{j}\Theta_{ij}(t)\,\big(f(x_j;t)-y_j\big)	(3.40)	40
E_{\theta(0)}\big\Theta(\theta(0))... \Theta(0)\equiv\mathbb \xrightarrow[m\to\infty]{}\ \Theta(t;\theta(t))\	(4.40)	40
e^{-\Theta(0)\,t}\,\big(f(0)-y\big) = f(t)-y	(5.40)	40]
e^{-\lambda_{\min}(\Theta(0))\,t}\,|e(0)| |e(t)|\le	(6.40)	40
G{(x,x') \dot}\mathcal + G(x,x') \mathcal = \Theta(x,x')	(7.40)	40
\Theta_{conv}(x,x') = x') T_g x,\ \Theta_{conv}(T_g	(8.40)	40
{حلّ (5.40) \text{تتجاوز f_{\text{real}}(t)\ \quad\Longrightarrow\quad \text{تتطوّر} \Theta(t)\	(9.40)	40
\underbrace{... ;\-;\ {{البناء z)]}_{\text{إعادة p(x\mid x)[\log E_{q(z\mid \underbrace{\mathbb p(x)\ge \log	(1.41)	41
p_z[\log(1-D(G(z)))] E_{z\sim D(x)]+\mathbb p_{data}}[\log E_{x\sim V(D,G)=\mathbb \min_G\max_D	(2.41)	41
J... \left|\det p_Z(x)\ = x}\right| f^{-1}}{\partial \left|\det\frac{\partial p_X(x)=p_Z\!\big(f^{-1}(x)\big)\	(3.41)	41
(1-\bar\alpha_t)\,I\big) N\!\big(\sqrt{\bar\alpha_t}\,x_0,\ x_0)=\mathcal q(x_t\mid	(4.41)	41
E_{t,x_0,\epsilon}\Big\big|\epsilon-\epsilon_\theta(\sqrt{\bar\alpha_t}\,x_0+... L_{\text{simple}}=\mathbb	(5.41)	41
x_{t-1}=\frac{1}{\sqrt{\alpha_t}}\Big(x_t-\frac{1-\alpha_t}{\sqrt{1-\bar\alpha_t}}\,\epsilon_\theta(x_t,t)\...	(6.41)	41]
p_t(x) s(x,t)=\nabla_x\log dx=f(x,t)\,dt+g(t)\,dw,\qquad	(7.41)	41
w dx=\big[f(x,t)-g(t)^2\,s(x,t)\big]\,dt+g(t)\,d\bar	(8.41)	41
\mathrm{FID}=|\mu_r-\mu_g|^2+\mathrm{Tr}\!\left(\Sigma_r+\Sigma_g-2(\Sigma_r\Sigma_g)^{1/2}\right)	(9.41)	41
c(x,y)\,d\gamma(x,y) \mathrm{OT}_c(p,q)=\min_{\gamma\in\Pi(p,q)}\int	(1.42)	42
E_q[f]\big) E_p[f]-\mathbb W_1(p,q)=\sup_{|f|_{\mathrm{Lip}}\le1}\big(\mathbb	(2.42)	42
H(\gamma)... C,\gamma\rangle-\varepsilon \mathrm{OT}_\varepsilon(p,q)=\min_{\gamma\in\Pi(p,q)}\big\langle	(3.42)	42
p_g[f(x)] E_{x\sim p_{data}}[f(x)]-\mathbb E_{x\sim \mathbb W_1(p_{data},p_g)=\sup_{|f|_{L\le1}}\	(4.42)	42]
p=q}\int|x-T(x)|^2\,dp(x) T_\# W_2^2(p,q)=\min_{T:\	(5.42)	42
F(\rho) \frac{1}{2\tau}\,W_2^2(\rho,\rho_n)+\mathcal \rho_{n+1}=\arg\min_\rho\	(6.42)	42
S_\varepsilon(p,q)=W_\varepsilon(p,q)-\tfrac12\,W_\varepsilon(p,p)-\tfrac12\,W_\varepsilon(q,q)	(7.42)	42

الجزء الثامن: بنى متقدّمة

الفصل	الوسم	الصيغة
43	(1.43)	D=\mathrm{diag}(d_1,\dots,d_n),... 0,&\text{وإلا}\end{cases},\qquad E\\ \{i,j\}\in A_{ij}=\begin{cases}1,&
43	(2.43)	u_k u_k=\lambda_k L 0=\lambda_1\le\lambda_2\le\cdots\le\lambda_n,\qquad U^\top,\qquad L=U\Lambda

E\{(x_i-x_j)^2 Lx=\sum_{\{i,j\}\in x^\top	(3.43)	43
\mathrm{Ncut}(A,B)=\mathrm{cut}(A,B)\Big(\tfrac1{\mathrm{vol}(A)}+\tfrac1{\mathrm{vol}(… B=V}\ \min_{A\sqcup	(4.43)	43
D^{-1/2}… A_{\mathrm{sym}}=\hat \hat A_{\mathrm{sym}}\,H^{(l)}W^{(l)}\big),\qquad H^{(l+1)}=\sigma\!\big(\hat	(5.43)	43
\pi(X))=\pi\,F(G,X) F(\pi(G),\	(6.43)	43
h_v^{(l)}=U\!… N(v){M\!\big(h_v^{(l-1)},h_u^{(l-1)},e_{uv}\big),\qquad m_v^{(l)}=\bigoplus_{u\in\mathcal	(7.43)	43
N(i){\exp\… \alpha_{ij}=\frac{\exp\!\big(\mathrm{LeakyReLU}(a^{\!\top}[Wh_i|Wh_j])\big)}{\sum_{k\in\mathcal	(8.43)	43
Q^\pi(s,a)=… S_t=s],\qquad E_\pi[G_t\mid V^\pi(s)=\mathbb r_{t+k+1},\qquad G_t=\sum_{k=0}^\infty\gamma^k	(1.44)	44
Q^… V^\star(s)=\max_a V^\star(s')\big],\qquad s,a)\big[R(s,a,s')+\gamma V^\star(s)=\max_a\sum_{s'}P(s'\mid	(2.44)	44
s,a)\big[R(s,a,s')+\gamma\max_{a'}Q^\star(s',a')\big] Q^\star(s,a)=\sum_{s'}P(s'\mid	(3.44)	44
Q^\pi(s,a) {\pi'(s)=\arg\max_a \text{تحسين: P^\pi)V^\pi=r^\pi,\qquad }(I-\gamma \text{تقييم:	(4.44)	44
Q(s,a)+\alpha\Big[r+\gamma\max_{a'}Q(s',a')-Q(s,a)\Big] Q(s,a)\leftarrow	(5.44)	44
E_… E_\pi\Big[\sum_{t}\nabla_\theta\log\pi_\theta(a_t|s_t)\,G_t\Big]=\mathbb J(\theta)=\mathbb \nabla_\theta	(6.44)	44
R(T)=\sum_{t=1}^T\big(… t}{N_a}\Big),\qquad a_t=\arg\max_a\Big(\hat\mu_a+c\sqrt{\tfrac{\ln } \text{UCB:	(7.44)	44
\theta\leftarrow\theta+\alpha\,\delta_t\,\nabla_… V_w(s_{t+1})-V_w(s_t),\qquad \delta_t=r_{t+1}+\gamma	(8.44)	44
V_w(s_t) w+\beta\,\delta_t\,\nabla_w w\leftarrow	(9.44)	44
… \forall\,\sigma_i,\ u_i(\sigma_i,\sigma_{-i}^\star)\qquad \ge\ u_i(\sigma_i^\star,\sigma_{-i}^\star)\	(1.45)	45
… \ BR_i(\sigma_{-i}^\star)\ \sigma_i^\star\in \text{بحيث:} \ \exists\,\sigma^\star\in\prod_i\Delta(A_i)\	(2.45)	45
Mq p^\top Mq=\min_{q\in\Delta}\max_{p\in\Delta} p^\top v=\max_{p\in\Delta}\min_{q\in\Delta}	(3.45)	45
{\dot\sigma_i(a)=… \text{منسوخ: a_i^t=BR_i\!\Big(\tfrac1t\sum_{\tau<t}a_{-i}^\tau\Big),\qquad } \text{وهميّ:	(4.45)	45
R^T(a) R_{\max}^T=\max_a R^T(a)=\sum_{t=1}^T\big(g^t(a)-g^t(a^t)\big),\qquad	(5.45)	45
\sigma_t(a)=\frac{w_t(a)}{\sum_{a'}w_t(a')} w_{t+1}(a)=w_t(a)\,e^{-\eta\mu^t(a)},\qquad	(6.45)	45
a_i,a_i' \forall i,\ \forall u_i(a_i',a_{-i})-u_i(a_i)=\Phi(a_i',a_{-i})-\Phi(a_i,a_{-i})\qquad	(7.45)	45
r_i^t\big]\quad\text{معتبراً E\big[\sum_t\gamma^t \mathbb \pi_i^\star=\arg\max_{\pi_i}\ الخصوم جزءاً من الب…	(8.45)	45
v_i,\dots,v_k] \partial_k[v_0,v_1,\dots,v_k]=\sum_{i=0}^k(-1)^i[v_0,\dots,\hat	(1.46)	46
H_k=Z_k/B_k Z_k,\qquad B_k=\mathrm{im}\,\partial_{k+1}\subseteq Z_k=\ker\partial_k,\qquad	(2.46)	46
f_k \chi=\sum_k(-1)^k\beta_k=\sum_k(-1)^k	(3.46)	46
}{ الميلاد-الموت) \text{متعدّدات \mathrm{PD}_k=\{b_i,d_i)\}\ \text{Persistence}=d-b,\qquad	(4.46)	46
|f-g|_\infty \le\ W_\infty\big(\mathrm{PD}(f),\mathrm{PD}(g)\big)\	(5.46)	46]
… sigma\ffi\mathrm{diam}(\sigma)\le\varepsilon,\qquad\لـ \text{السيمبلكس \mathrm{Rips}(X,\varepsilon):\	(6.46)	46
d-t)\ t\mapsto\min(t-b,\ \(b,d){الكونيّة \lambda_k(t)=\text{القيمة	(7.46)	46
\mathrm{id}_A f=f=f\circ \mathrm{id}_B\circ f),\qquad f=h\circ(g\circ g)\circ (h\circ	(1.47)	47
F(\mathrm{id}_A)=\mathrm{id}_{F(A)} F(f),\qquad f)=F(g)\circ F(g\circ	(2.47)	47
}{الطبيعيّة) F(h)\qquad\text{مربّع G(h)\circ\alpha_A=\alpha_B\circ	(3.47)	47
{X,Y في C}(X,G(Y))\qquad\text{طبيعياً \mathrm{Hom}_{\mathcal \cong\ D}(F(X),Y)\ \mathrm{Hom}_{\mathcal	(4.47)	47
\lambda_A:I… C),\qquad A\otimes(B\otimes \} \cong\ \xrightarrow{\ C\ B)\otimes \alpha_{A,B,C}:(A\otimes	(5.47)	47
\text{(ضرب)} T\ \mu:T^2\Rightarrow \text{(وحدة)},\qquad T\ C}\Rightarrow \eta:\mathrm{Id}_{\mathcal	(6.47)	47
T T\eta=\mathrm{id}_T=\mu\circ\eta \mu\circ T,\qquad T\mu=\mu\circ\mu \mu\circ	(7.47)	47
S A\to set:S\times A,\qquad get:S\to	(8.47)	47
C\to\mathfb{Set} I:\mathcal	(9.47)	47
A' B'\to P\times \text{backward}:\ B,\qquad \to\ A)\ (P,\ \text{layer}:\	(10.47)	47
R^n \mathbb \cong\ {p\ المشتقّات عند T_pM=\text{اتجاهات	(1.48)	48
ds^2=g_{ij}\,dx^idx^j |\gamma|_g=\int\sqrt{g_p(\dot\gamma,\dot\gamma)}\,dt,\qquad	(2.48)	48
x^j=0 x^i\dot x^k+\Gamma^k_{ij}\dot \ddot	(3.48)	48
X\,g(Y,Z)=g(\nabla_XY,Z)+g(Y,\nabla_XZ) \nabla_XY-\nabla_YX=[X,Y],\qquad	(4.48)	48
R(X,Y)Z=\nabla_X\nabla_YZ-\nabla_Y\nabla_XZ-\nabla_{[X,Y]}Z	(5.48)	48
K(X,Y)=\frac{g(R(X,Y)Y,X)}{|X|^2|Y|^2-g(X,Y)^2}	(6.48)	48
\theta_{t+1}=R_x\big(\theta_t-\eta\,\tilde… L(\theta),\qquad L(\theta)=F(\theta)^{-1}\nabla \tilde\nabla	(7.48)	48
|f(x)-f(y)|_g \approx\ M}(x,y)\ d_\mathcal	(8.48)	48
E_\theta\partial_i… E_\theta\big[\partial_i\ell\,\partial_j\ell\big]=-\mathbb g_{ij}(\theta)=\mathbb	(9.48)	48

الجزء التاسع: المتسلسلات ومعالجة الإشارة

الفصل	الوسم	الصيغة
49]	(1.1.49)	a_n \sum_{n=1}^{N} = S_N \qquad S_N, \lim_{N\to\infty} ;\=;\ a_n \sum_{n=1}^{\infty}
49	(1.2.49)	<\infty a_n \sum \;\Longrightarrow\; b_n<\infty \sum b_n,\ a_n\le 0\le \text{(مقارنة)}\quad
49	(2.2.49)	L… L<1\Rightarrow\text{تقارب},\quad L=\lim_{n\to\infty}\frac{a_{n+1}}{a_n}:\quad quad\} دالامبر) \text{نسبة،
49	(3.2.49)	L>1… L<1\Rightarrow\text{تقارب},\quad L=\lim_{n\to\infty}\sqrt[n]{a_n}:\quad quad\} كوشي) \text{جذر،
49	(4.2.49)	\int_{1}… \ffi \sum_{n=1}^{\infty}a_n<\infty \;\Longrightarrow\; f(n)=a_n \,0 f\searrow \text{(تكاملي)}\quad
49	(5.2.49)	r>1\Rightarrow\text{تقا… n\!\left(\frac{a_n}{a_{n+1}}-1\right)=r:\quad \lim_{n\to\infty} \text{(رابه)}\quad
49	(1.3.49)	ت… \text{ a_{\sigma(n)} }\sum متقاربة، وكلّ إعادة ترتيب \text{ a_n \sum \;\Longrightarrow\; \sum|a_n|<\infty
49	(2.3.49)	… و متقاربة، \text{ \sum_{n=1}^{\infty}(-1)^{n+1}a_n \;\Longrightarrow\; 0 a_n\searrow \text{(لايبنتس)}\quad
49	(3.3.49)	R… S\in\overline{\mathbb \forall \;\Rightarrow\; شرطية} \text{ a_n \sum quad\} في إعادة الترتيب) \text{ريمان
49	(4.3.49)	… c_n b_n \sum \;\Longrightarrow\; c_n\searrow0 { محدودة، \text{ N}b_n A_N=\sum_{n\le \text{(ديريكلِه)}\quad
49	(1.4.49)	R\in[0,\infty] \frac{1}{R}=\limsup_{n\to\infty}\sqrt[n]{|a_n|},\qquad
49	(2.4.49)	\text{تب… \Rightarrow |z-z_0|>R qquad\,}{مطلق (وموحّد على كل قرص مغلق أصغر) \text{تقارب \Rightarrow |z-z_0|<R

$$\sum\int = \int\sum a_n(z-z_0)^{n-1},\qquad n a_n(z-z_0)^{n}=\sum \frac{d}{dz}\sum {R:\quad \text{داخل}$$ (3.4.49) 49

$$\Big\|\sum_{k... (I-A)^{-1}=\sum_{k=0}^{\infty}A^{k},\qquad \;\Longrightarrow\; \rho(A)<1 \text{(نيومان)}\quad$$ (4.4.49) 49

$$D}\Big\|\sum_{n=1}^{N}u_n(x)-S(x)\Big\|\;\xrightarrow[N\to\infty]{}\;0 \sup_{x\in$$ (1.5.49) 49

$$... u_n \sum \;\Longrightarrow\; M_n<\infty \sum D,\quad x\in \forall \ M_n\ \|u_n(x)\|\le M)}\quad \text{معيار)$$ (2.5.49) 49

$$u_n S=\sum_n\int_D \int_D { \text{ متصلة، و } S \;\Longrightarrow\; ;\text{ حدود متصلة} + \text{موحّد}$$ (3.5.49) 49

$$... u_n' \sum { إذا \text{ u_n' u_n\Big)'=\sum \Big(\sum quad\:}\text{للتفاضل يشترط موحّداً للمتسلسلة المشتقة}:$$ (4.5.49) 49

$$a_n=[z^{n}]A(z) A(z)=\sum_{n\ge0}a_nz^{n},\qquad quad\}(\text{ دالة مولّدة عادية}$$ (1.6.49) 49

$$A(z)=\frac{P(z)}{1-... \;\Longrightarrow\; a_n=\sum_{k=1}^{K}c_ka_{n-k} \text{ تكرارية خطّية ثابتة المعاملات: }$$ (2.6.49) 49

$$Z\{x_{n-1}\}=z^{-1}X(z) \mathcal X(z)=\sum_{n\ge0}x_nz^{-n},\qquad quad\}(\text{ تحويل Z وخاصية الإزاحة)}$$ (3.6.49) 49

$$\quad \text{ دالة التحويل} H(z)=\frac{Y(z)}{X(z)} Z\{(h*x)_n\}=H(z)\,X(z),\qquad \mathcal \text{(الالتفاف)}\}$$ (4.6.49) 49

$$\quad \text{(الاستقرار)}\}(\text{النظام} \text{ مستقرٌّ} \ffi \text{(BIBO)}\}\text{ كلّ أقطابه داخل دائرة الوحدة} H(z) ...$$ (5.6.49) 49

$$\quad... S \;\xrightarrow[N\to\infty]{}\; \sigma_N=\frac{1}{N}\sum_{k=1}^{N}S_k \text{(سيزارو)}\}\quad$$ (1.7.49) 49

$$\lim_{r\to1^-}\}A(r) \overset{A}{=} a_n \sum r<1),\qquad (0\le A(r)=\sum_{n\ge0}a_nr^{n}\ \text{(أبيل)}\}\quad$$ (2.7.49) 49

$$\overset{A... a_n \sum \;\Longrightarrow\; \text{ بالمفهوم التقليدي} a_n=S \sum quad\}\text{ أبيل للحدّ}\}\text{ نظرية)}$$ (3.7.49) 49

$$U_n=... \sum_{n=p}^{q}\{u_nv_n=U_qv_q-U_{p-1}v_p+\sum_{n=p}^{q-1}U_n(v_n-v_{n+1}),\quad quad\}\text{ أبيل)}\text{ تجزيء}$$ (4.7.49) 49

$$f,e_k\rangle\big\|^{2}\;\le\;\|f\|^{2} \sum_{k}\big\|\langle \text{ بيسل)}\}\quad$$ (1.8.49) 49

$$f,e_k\rangle\big\|^... \sum_{k}\big\|\langle \;\Longrightarrow\; \text{ أساس كامل} e_k\}\text{ }\text{ (بارسيفال)}\}\quad$$ (2.8.49) 49

$$\sum_{k... \text{ هو } E_N=\mathrm{span}\{e_1..e_N\}\text{ في f}\text{ تقريب لـ} \text{ أفضل quad}\}\text{ تقريب)}$$ (3.8.49) 49

$$f,e_k\rangle\|^{2} N\|\langle \|f-P_Nf\|^{2}=\|f\|^{2}-\sum_{k\le quad}\}\text{ خطأ)}\text{ التقريب}$$ (4.8.49) 49

$$nx}{\sqrt{\pi}}\Big\}_{n\ge1} \tfrac{\sin nx}{\sqrt{\pi}},\ \tfrac{\cos \Big\{\tfrac{1}{\sqrt{2\pi}},\$$ (1.1.50) 50

$$nx\big) nx+b_n\sin \frac{a_0}{2}+\sum_{n=1}^{\infty}\big(a_n\cos f(x)\sim$$ (1.2.50) 50

$$b_n=\frac{1}{\pi}\int_{-\pi}^{\pi}f(x)\sin(nx)\,dx a_n=\frac{1}{\pi}\int_{-\pi}^{\pi}f(x)\cos(nx)\,dx,\qquad$$ (2.2.50) 50

$$\int_{-\pi}^{\pi}\sin(nx)\sin(mx)\,dx=\pi\delta_... \int_{-\pi}^{\pi}\cos(nx)\cos(mx)\,dx=\pi\delta_{nm},\quad$$ (3.2.50) 50

$$a_n=0 \{f\Rightarrow \text{فردية} b_n=0,\qquad \{f\Rightarrow \text{زوجيّة}$$ (4.2.50) 50

$$\{x \text{ عند} f(x)\quad S_N(x)\to \text{ كلّ نقطة استمرار}$$ (1.3.50) 50

$$\{\text{قفزة} \text{ عند} \frac{f(x^{+})+f(x^{-})}{2}\quad S_N(x)\to$$ (2.3.50) 50

$$D_N(t)=\frac{... S_N(x)=\frac{1}{2\pi}\int_{-\pi}^{\pi}f(x-t)\,D_N(t)\,dt,\quad \text{ تمثيل بالمجموع الجزئي: }$$ (4.3.50) 50

$$t}{t}\,... \sup_{x}S_N(x)\;\xrightarrow[N\to\infty]{}\;\frac{J}{2}\Big(1+\frac{2}{\pi}\int_{0}^{\pi}\frac{\sin$$ (1.4.50) 50

$$O(1/N) x_0\pm \text{ موضعه} \text{ المطلق} \text{التجاوز} J,\qquad,\08949.0 approx$$ (2.4.50) 50

$$\text{الخطأ} \text{ بمعنى } :L^{2}\to0 \quad\text{رغم} \|f-S_N\|_2\to0$$ (3.4.50) 50

$$\frac{1}{2\pi}\int_{-\pi}^{\pi}\|f(x)\|^{2}dx=\frac{\|a_0\|^{2}}{4}+\frac{1}{2}\sum_{n=1}^{\infty}\big(\|a_n\|^{2}...$$ (1.5.50) 50

$$\frac{1}{2\pi}\int\|f\|^{2}=\sum_{k=-\infty}^{\infty}\|c_k\|^{2} \quad\text{ المركّبة:}\text{ بالصيغة}$$ (2.5.50) 50

$$c_k(f)\,\overline{c_k(g)} g=\sum_k f\bar \frac{1}{2\pi}\int quad\}:\text{ (جداء داخلي)}\text{ معمّمة}$$ (3.5.50) 50

$$\|f-S_N\|^{2}_{L^{2}}=2\pi\sum_{\|k\|>N}\|c_k\|^{2} \quad\}:\text{ الاقتطاع}\text{ وخطأ}$$ (4.5.50) 50

$$... \int\|D_N\|\sim \int_{-\pi}^{\pi}D_N=2\pi,\qquad D_N(t)=\frac{\sin\big((N+\tfrac12)t\big)}{\sin(t/2)},\qquad$$ (1.6.50) 50

$$0 \ge K_N(t)=\frac{1}{N}\sum_{k=0}^{N-1}D_k(t)=\frac{1}{N}\left(\frac{\sin(Nt/2)}{\sin(t/2)}\right)^{2}\$$ (2.6.50) 50

$$\{f... \text{ موحّداً لكلّ} f \sigma_N\to \;\Longrightarrow\; f(x-t)K_N(t)\,dt \sigma_N(x)=\frac{1}{2\pi}\int$$ (3.6.50) 50

$$\|f-\sigma_N\|_2\to0 \quad\}:\text{ فقط} L^{2}\text{ } \{f\in \text{ وإذا}$$ (4.6.50) 50

$$c_k=\frac{1}{2\pi}\int_{-\pi}^{\pi}f(x)e^{-ikx}\,dx f(x)=\sum_{k=-\infty}^{\infty}c_k\,e^{ikx},\qquad$$ (1.7.50) 50

$$c_0=\frac{a_0}{2} (k\ne0),\qquad c_k=\frac{a_{\|k\|}-i\,b_{\|k\|}\,\mathrm{sgn}(k)}{2}\$$ (2.7.50) 50

$$\{\text{ هيرميتي} c_{-k}=\overline{c_k}\quad\text{ تماثل)}\;\Longrightarrow\; \text{ حقيقية} f\text{ }$$ (3.7.50) 50

$$\|c_k(g)\|=\|c_k(f)\| c_k(g)=e^{-ikx_0}c_k(f),\qquad g(x)=f(x-x_0)\Rightarrow \text{ إزاحة:}$$ (4.7.50) 50

$$N\}c_ke^{ikx} P_Nf=\sum_{\|k\|\le quad}\}N\text{ معاملاً في القاعدة المثلثية:}\text{ تقريب بـ} \text{ أفضل}$$ (1.8.50) 50

$$\min_{\Lambda}\|f-\sum_{k\in\Lambda}c_... \|\Lambda\|=N:\quad \}\Lambda,\text{ لكن} \text{ الأمثل على أيّ مجموعة معاملات}$$ (2.8.50) 50

$$\text{greedy)}\{ \text{ معاملات بالمقدار (قاعدة الاختيار النهم} N\text{ } \Lambda^{\star}=\text{ أكبر}$$ (3.8.50) 50

$$\{\text{ قطعيّاً} C^{m}\text{ لدالة} \|c_k\|=O(k^{-(m+1)})\text{ }\text{ اضمحلال الذيل يحكم الدقّة: } \text{ ومعدّل}$$ (4.8.50) 50

$$x(t)=\frac{1}{2\pi}... \{ \text{دوريّة:} \text{ غير} \quad\longrightarrow\quad c_ke^{ikx} f(x)=\sum_k \text{ دوريّة}$$ (1.1.51) 51

$$x(t)=\frac{1}{2\pi}\int_{-\infty}^{\infty}... t}\,dt,\qquad X(\omega)=\int_{-\infty}^{\infty}x(t)\,e^{-i\omega$$ (1.2.51) 51

$$F\{ax+by\}=aX+bY \mathcal \{ \text{خطّية}:$$ (2.2.51) 51

$$F\{x(at)\}=... \mathcal \{ \text{تحجيم}: t_0}X(\omega),\qquad F\{x(t-t_0)\}=e^{-i\omega \mathcal \{ \text{إزاحة}:$$ (3.2.51) 51

$$F\Big\{\int_{-\infty}^{t}x... \mathcal \{ \text{تكامل}: X(\omega),\qquad F\{x'\}=i\omega \mathcal \{ \text{تفاضل}:$$ (4.2.51) 51

$$F\{x(t)e^{i\omega_0t}\}=X(\omega-\omega_0) \mathcal \{ \text{تعديل}:$$ (5.2.51) 51

$$(pi\2 بـ n\quad(\text{دوري} X(e^{i\omega})=\sum_{n=-\infty}^{\infty}x[n]e^{-i\omega } \text{DTFT:}$$ (1.3.51) 51

$$k=0..N-1 i/N},\qquad W_N=e^{-2\pi X[k]=\sum_{n=0}^{N-1}x[n]\,W_N^{kn},\qquad } \text{DFT:}$$ (2.3.51) 51

$$x[n]=\frac{1}{N}\sum_{k=0}^{N-1}X[k]\,W_N^{-kn} } \text{IDFT:}$$ (3.3.51) 51

$$X[k+N/2]=E[k]-W_N^{k}O[k] X[k]=E[k]+W_N^{k}O[k],\quad } \text{ (Cooley–Tukey): FFT}$$ (4.3.51) 51

$$f=\frac{f_s}{N} \Delta } \text{ ودقّة التردّد} N),\qquad T(N)=2T(N/2)+O(N)=O(N\log } \text{التعقيد:}$$ (5.3.51) 51

$$\mathrm{sinc}(u)=... x(t)=\sum_{n=-\infty}^{\infty}x(nT_s)\,\mathrm{sinc}\!\left(\frac{t}{T_s}-n\right),\qquad$$ (1.4.51) 51

$$f_s=\frac{1}{T_s}\;>\;2B } \text{ شرط} \text{ نيكويست:}$$ (2.4.51) 51

$$... X_s(\omega)=\frac{1}{T_s}\sum_{k=-\infty}^{\infty}X(\omega-k\omega_s),\qquad } \text{ في} \text{ مجال التردّد:}$$ (3.4.51) 51

$$\omega_s>2\omega_B \ffi \omega_s-\omega_B>\omega_B } \text{ ffi: ممنوع} \text{ التداخل}$$ (4.4.51) 51

$$Z }k\in\mathbb f_{\text{مرئي}}=|f_{\text{أصلي}}-fk_s|\quad\text{ لأقرب} } \text{ تحت نيكويست: } \text{العيّنة}$$ (1.5.51) 51

$$\text{طيّ}\text{ الطيف: } \} \text{ التداخل} \Rightarrow\ X(\omega-k\omega_s)\ X_s(\omega)=\frac{1}{T_s}\sum_k \text{ يجمع الط...}$$ (2.5.51) 51

المكافحة: $$ H_{\text{LP}}(\omega)=0\ f_s,\qquad \text{ثم العيّنة بـ } (h_{\text{LP}}*x)\ = x \tilde{ \text{	(3.5.51)	51
الطاقة $$ E_{\text{alias}}=\int_{\|\omega|>\omega_s/2}\|X(\omega)\|^2 d\omega $$ المشوّهة:	(4.5.51)	51
$$ x\}=\frac{1}{2\pi}(H*X)(\omega) F\{h\cdot \mathcal F\{h*x\}=H(\omega)\,X(\omega),\qquad \mathcal	(1.6.51)	51
$$ \text{DFT}\{\text{zeropad}(h)\}\,X[k] \;\rightleftharpoons\; h_kx_{n-k} (h*x)[n]=\sum_k $$ منفصلاً:	(2.6.51)	51
$$ X_w(\omega)=\frac{1}{2\pi}(X*W)(\omega) \;\Rightarrow\; x_w[n]=x[n]w[n] $$ النافذة:	(3.6.51)	51
$$ \Delta\omega_{\text{فصّ}}\cdot\text{ مستوى } \approx\text{ثابت للنافذة} $$ مفاضلة النافذة: الفصوص	(4.6.51)	51
$$ R_x(0)=\mathbb E\big[x(t)\overline{x(t-\tau)}\big],\qquad R_x(\tau)=\mathbb E\|x\|^2=\text{القدرة} $$	(1.7.51)	51
$$ R_x(\tau)e^{-i\omega\tau}d\tau F\{R_x\}(\omega)=\int S_x(\omega)=\mathcal \text{ (فينر–خينتشين)}\quad $$	(2.7.51)	51
$$ S_x(\omega)=\sigma^2\ \;\Rightarrow\; R_x(\tau)=\sigma^2\delta(\tau) $$ ضجيج أبيض: $$ \text{ثابت} $$	(3.7.51)	51
$$ \alpha\approx1 S_x(\omega)\propto\frac{1}{\|\omega\|^\alpha},\qquad \text{ضجيج } 1/f: $$	(4.7.51)	51
$$ S[k]=\frac{1}{N}\|X[k]\|^2 $$ تقدير عملي (periodogram):	(5.7.51)	51
$$ t\|f_0-f^\star\|_k,\quad e^{-\lambda_k \approx \|f_t-f^\star\|_k $$ ديناميكية التعلّم في فضاء NTK:	(1.8.51)	51
$$ t_k\approx\frac{1}{\lambda_k}\log\frac{\|c_k(0)\|}{\varepsilon}\quad k: $$ زمن تعلّم المكوّن	(2.8.51)	51
$$ N(0,\sigma^2 B\sim\mathcal \sin(Bx)\big],\quad \phi(x)=\big[\cos(Bx),\ $$ ميزات فوريه العشوائية (RFF):	(3.8.51)	51
$$ O(n\log n) \text{ تكلفة } \Rightarrow F(x)\big) F^{-1}\big(R\cdot\mathcal y=\mathcal $$ طبقة مزج طيفي (FNet):	(4.8.51)	52
$$ \text{كم من التردّد «} Tx\; $$ فوريه: $$ \text{STFT/مويجات}: \;\longrightarrow\; X(\omega) $$	(1.1.52)	52
$$ \frac{1}{2} \;\ge\; \Delta_t\,\Delta_\omega $$	(1.2.52)	52
$$ x(t)=\exp\!\Big(-\frac{(t-t_0)^2}{2\sigma^2}+i\omega_0t\Big) $$ والمساواة للغاوسي فقط:	(2.2.52)	52
$$ t\Delta f\approx\frac{f_s}{N},\quad \Delta N,\quad t\approx \Delta $$ في الصورة المنفصلة (STFT):	(3.2.52)	52
$$ \text{لا } $$ مبرهنة بنديكت–تيان–فان (Balian–Low): يمكن لقاعدة غابور أن تكون موضعية جيداً ومتعمّدة في آن	(4.2.52)	52
$$ kn/N} i X[m,k]=\sum_{n=0}^{N-1}x[n+mH]\,w[n]\,e^{-2\pi} $$	(1.3.52)	52
$$ F_{jk}S[m,k]\Big) M[m,j]=\log\!\Big(\sum_k $$ المخطوط الطيفي: $$ \text{log-mel: } S[m,k]=\|X[m,k]\|^2,\qquad $$	(2.3.52)	52
$$ N/4) \text{ بقفزة } \text{Hann } n\quad(\text{مثل } \forall w[n-mH]=1\ \sum_m $$ شرط إعادة البناء (OLA):	(3.3.52)	52
$$ N\Big) N\log O\Big(\frac{L}{H}\cdot $$ التكلفة:	(4.3.52)	52
$$ R b\in\mathbb a>0,\ a\,\psi\!\left(\frac{t-b}{a}\right),\qquad \psi_{a,b}(t)=\frac{1}{\sqrt} $$	(1.4.52)	52
$$ x,\psi_{a,b}\rangle x(t)\,\overline{\psi_{a,b}(t)}\,dt=\langle W_x(a,b)=\int \text{(CWT)}\quad $$	(2.4.52)	52
$$ C_\psi=\int_0^\infty\frac{\|\Psi(\omega)\|^2}{\omega}d\omega<\infty \text{ (admissibility):}\quad $$ شرط القبول	(3.4.52)	52
$$ W_x(a,b)\,\psi_{a,b}(t)\,\frac{da\,db}{a^2} x(t)=\frac{1}{C_\psi}\iint \quad $$ إعادة البناء:	(4.4.52)	52
$$ f\approx\frac{f_c}{a}\quad(f_c\text{ } $$ المقياس ترددًا: التردّد المركزي للمويجة	(5.4.52)	52
$$ g_n\,\phi(2t-n) \psi(t)=\sqrt2\sum_n h_n\,\phi(2t-n),\qquad \phi(t)=\sqrt2\sum_n $$	(1.5.52)	52
$$ g_{n-2k}\,cA_{j-1}[n] cD_j[k]=\sum_n h_{n-2k}\,cA_{j-1}[n],\qquad cA_j[k]=\sum_n $$ بنك التحليل:	(2.5.52)	52
$$ \sum_{\dots} h_nh_{n-2k}=\delta_{k},\qquad \sum_n g_n=(-1)^{n}h_{L-1-n},\qquad $$ الشرط الثنائي (quadrature):	(3.5.52)	52
$$ L^2}=\overline{V_0\oplus\bigoplus_{j\ge0}W_j} W_j,\qquad V_{j+1}=V_j\oplus $$ MRA:	(4.5.52)	52
$$ N4+\cdots}_{<2N}=O(N) N2+\tfrac \underbrace{N+\tfrac $$ التعقيد:	(5.5.52)	52
$$ \text{عتبة} 0,&\|c\|\le\lambda\end{cases}\qquad c=\begin{cases}c,&\|c\|>\lambda\\ \hat{ $$ عتبة صلبة (hard):	(1.6.52)	52
$$ \hat\sigma=\frac{\mathrm{MAD} N},\qquad \lambda=\sigma\sqrt{2\ln $$ العتبة العالمية (Donoho–Johnstone):	(2.6.52)	52
$$ \mathrm{SURE}(\lambda) \lambda^\star=\arg\min_\lambda\ $$ مخاطرة Stein غير المتحيّزة (SURE):	(3.6.52)	52
$$ f-f\|^2\approx\sum_k\min(c_k^2,\sigma^2}) E\|\hat \mathbb $$ الخطأ المتوقّع (oracle):	(4.6.52)	52
$$ x\!\left(t+\tfrac{\tau}{2}\right)\overline{x\!\left(t-\tfrac{\tau}{2}\right)}\,e^{-i} W_x(t,\omega)=\int $$	(1.7.52)	52
$$ W\,dt=\|X(\omega)\|^2},\quad \frac{1}{2\pi}\int W\,d\omega=\|x(t)\|^2},\quad \int $$ خصائص مرغوبة:	(2.7.52)	52
$$ W_x=W_{x_1}+W_{x_2}+2\Re\{W_{x_1x_2}\} \Rightarrow x=x_1+x_2 $$ الحدود المتقاطعة:	(3.7.52)	52
$$ t+\tau\omega)}A_x(\theta,\dots C_x(t,\omega)=\iint\phi(\theta,\tau)e^{-i(\theta $$ العلاج (عائلة كوهين):	(4.7.52)	52
$$ S_2x=\|\,\big\|\,\|x*\psi_{\lambda_1}\|*\psi_{\dots S_1x=\|\|x*\psi_{\lambda_1}\|*\phi\|},\qquad S_0x=x*\phi, $$	(1.8.52)	52
$$ \|Sx-Sy\|\le\|x-y\| $$ الثبات للترجمة: كلما زاد العمق $$ \|S(x_c)-S(x)\|\to0 $$ مقيساً بالمقياس	(2.8.52)	52
$$ N) O(\log $$ عدم التوسّع (nonexpansive):	(3.8.52)	52
$$ \|H(e^{i\omega})\|=\dots H(z)=\frac{Y(z)}{X(z)}=\frac{\sum_{k=0}^{M}b_kz^{-k}}{1+\sum_{k=1}^{N}a_kz^{-k}},\qquad $$ لكلّ مسار، وعدد المسارات N) O(N\log $$ التعقيد:	(4.8.52)	52
$$ h_kz^{-k} H(z)=\sum_k y[n]=\sum_{k=0}^{L-1}h_kx[n-k],\qquad $$ FIR:	(1.1.53)	53
$$ H(z)=\frac{B(z)}{A(z)} y[n]=\sum_{k=0}^{M}b_kx[n-k]-\sum_{k=1}^{N}a_ky[n-k],\qquad $$ IIR:	(1.2.53)	53
$$ \|z\|\lt1 \text{ داخل } H\text{ أقطاب } \text{كلّ } \;\Longleftrightarrow\; \sum\|h[n]\|\lt\infty $$ الاستقرار (BIBO):	(2.2.53)	53
$$ H(\omega)=-\omega\frac{L-1}{2} \arg \Rightarrow h_k=h_{L-1-k} $$ الطور الخطّي (FIR متماثل):	(3.2.53)	53
$$ f\text{ f/f_s}\quad(\Delta L\approx\frac{4}{\Delta } $$ طول FIR بنافذة: عرض الانتقال	(4.2.53)	53
$$ Y(\omega)=W(\omega)X(\omega) y[n]=\sum_{k=0}^{L-1}w_k\,x[n-k]\quad\Longleftrightarrow\quad $$	(5.2.53)	53
$$ L) N+L\log O(N\log \text{ FFT: تكلفة } L),\qquad O(N\cdot $$ تكلفة مباشرة:	(1.3.53)	53
$$ \text{ 16}\text{ بحسب العتاد والدفعات} $$ نقطة التعادل العملية: $$ \text{64 } L^\star\approx $$	(2.3.53)	53
$$ k} w_ke^{-i\omega W(\omega)=\sum_k $$ الاستجابة الترددية المتعلّمة:	(3.3.53)	53
$$ k] y[n]=\sum_{k=0}^{K-1}w_k\,x[n-d\cdot $$	(4.3.53)	53
$$ R=1+(K-1)\sum_{j=0}^{L-1}2^j\}=1+(K-1\dots \text{ ونواة } K:\quad\{1,2,4,\dots,2^{L-1}\} $$ حقل استقبالي بتوسيعات	(1.4.53)	53
$$ d} \text{ لكلّ طبقة — مستقل عن } K)\text{ } O(N\cdot $$ التعقيد:	(2.4.53)	53
$$ W_d(\omega)=W(d\omega)\text{ } \Rightarrow d} $$ في مجال التردّد: توسيع (ضغطٌ للطيف)	(3.4.53)	53
$$ O\dots \text{ التكلفة: } d\right)V,\qquad \text{Attention}(Q,K,V)=\mathrm{softmax}\!\left(\frac{QK^\top}{\sqrt} $$	(4.4.53)	53
$$ \dots \big(\phi(Q)\phi(K)^\top\big)V=\phi(Q)\big(\phi(K)^\top V\big)\Rightarrow $$ انتباه خطّي (kernel):	(1.5.53)	53
$$ n\,d) O(n\log F(x)\big)\Rightarrow \mathcal F^{-1}\big(R\odot y=\mathcal $$ مزج فوريه (FNet):	(2.5.53)	53
$$ O(n(w+r+s)) $$ نوافذ محلية + عالمية (Longformer/BigBird):	(3.5.53)	53
	(4.5.53)	53

$y(t)=Ch(t)\ h'(t)=Ah(t)+Bx(t),\qquad$	(1.6.53)	53
$A/2)^{-1}(I+\dots\ A=(I-\Delta \bar x_n,\quad B\ h_{n-1}+\bar A\ h_n=\bar\ \{\Delta\text{}):$ بخطوة) $\text{}$ بالتفريد	(2.6.53)	53
$\dots\ \Rightarrow B\ A^{k}\bar K_k=C\bar \bar K_k\,x_{n-k},\qquad y_n=\sum_{k=0}^{n}\bar\ \{$ التفاف: $\text{}$ كنواة	(3.6.53)	53
$n<k\end{cases}\ &,0\ n=k\\ n+1,& n>k\\ A_{nk}=-\begin{cases}(2n+1)^{1/2}(2k+1)^{1/2},& \}$ HiPPO: $\text{}$ تهيئة	(4.6.53)	53
$\tau\approx\frac{1}{1-\rho}$ الذاكرة $\text{}$ زمن $A)<1,\qquad \rho(\bar\ \{$ الاستقرار $\text{}$ والذاكرة:	(5.6.53)	53
$(طيف/نص)\ c=\text{}$ شرط $x_{<t},c\big),\qquad p(x)=\prod_{t=1}^{T}p\big(x_t\mid\ \{$ توليد $\text{}$ تلقائي:	(1.7.53)	53
$E[\log(1-D(G(c)))]\ D(x)]+\mathbb E[\log \mathbb \min_G\max_D\ \}:($ GAN $)$ المولّد $\text{}$ فقدان	(2.7.53)	53
$x)\big\|_1\ L_{\mathrm{mel}}=\sum_{s}\big\|\phi_s(x)-\phi_s(\hat \mathcal\ \{$ طيفي متعدد المقاييس: $\text{}$ فقدان	(3.7.53)	53
$x_{t-1}=\frac{1}{\sqrt{\alpha_t}}\Big(x_t-\frac{1-\alpha_t}{\sqrt{1-\bar\dots\ \{$ على الإشارة: $\text{}$ الانتشار	(4.7.53)	53
$1\}k\notinf_0,f_\dots\ 1\}m\notin[t_0,t_0+t]\}\cdot\mathfb S[m,k]=S[m,k]\cdot\mathfb \tilde\ \{\text{}$SpecAugment:	(1.8.53)	53
$L=-\log\frac{\exp(\mathrm{sim}(q_t,c_t)/\kappa)}{\sum_{\dots\ \mathcal\ \{$ توقع $\text{}$ مُقنَّع $:(0.2$ (MAM/wav2vec	(2.8.53)	53]
$E\log\frac{e^{f(x)^{T}f(x^{+})/\tau}}{e^{f(x)^{T}f(x^{+})}\dots\ L=-\mathbb \mathcal\ \{$ (contrastive): $\text{}$ تناقضي	(3.8.53)	53
$R(h)+\text{}$ فجوة $R(h)\le \hat\ \{$ تنظيم $\text{}$ بالتكبير: $R(h)$ التكبير	(4.8.53)	53
$E\{(x_i-x_j)^{2}=x^{\top}Lx\ L(x)=\frac12\sum_{(i,j)\in \mathcal L=D-A,\qquad$	(1.1.54)	54
$\text{}$ تحويل $\dots\ x,u_k\rangle\ x_k=\langle \hat \lambda_1\le\cdots\le\lambda_N,\qquad U^{\top},\quad L=U\Lambda$	(2.1.54)	54
$x\ x=U\hat x=U^{\top}x,\qquad \hat\ \{\text{}$GFT:	(1.2.54)	54
$g(\Lambda)=\mathrm{diag}(g(\lambda_1),\dots,g(\dots\ y=U\,g(\Lambda)\,U^{\top}x,\qquad \{$ طيفي $\text{}$ مرشّح	(2.2.54)	54
$y\dots\ \Rightarrow g(\lambda)\approx\sum_{k=0}^{K}\theta_kT_k(\tilde\lambda)\ \}$ (ChebNet): كثير حدود $\text{}$ تقريب	(3.2.54)	54
$x_k\|^{2}\ L(x)=\sum_k\lambda_k\|\hat \mathcal x_k\|^{2},\qquad \|x\|^{2}=\sum_k\|\hat\ \{$ الطاقة $\text{}$ الطيفية:	(4.2.54)	54
$v_t)_k\big)(x)\Big)\ F\ F^{-1}\big(R_k\cdot(\mathcal v_{t+1}(x)=\sigma\Big(Wv_t(x)+\mathcal$	(1.3.54)	54
$\{O(N^{2})$ لا $N)\text{}\ \{O(N\log \text{}$ التكلفة Rightarrow $\{$ فقط $K\text{}\ k\|\|e\|\|$ نحتفظ بـ $\}$ $\text{}$ الاقتطاع:	(2.3.54)	54
$\text{}$ حياد $\text{}$ الدقة: الأوزان $R_k\text{}$ في فضاء الدوالّ لا يعتمد على شبكة العيّنات	(3.3.54)	54
$\underbrace{\varepsilon_{\text{}(اقتطاع}}_{\text{}$ ذيل $G_\theta\|\le G-\mathcal \|\mathcal\ \}\text{}$ الخطأ: $\dots$ الطي	(4.3.54)	54
$\min_\theta\sum_{p}\|f_\theta(p)-I(p)\|^{2}\ f_\theta(x,y)\to(R,G,B),\qquad \{\text{}$INR:	(1.4.54)	54
$z_{\ell-1}+b_\ell)\ z_{\ell}=\sin(W_\ell W_0x+b_0),\quad z_1=\sin(\omega_0\ \}\ \text{}$SIREN:	(2.4.54)	54
$N(0,\sigma^{2})\ B\sim\mathcal Bx)\big],\quad \sin(2\pi Bx),\ \gamma(x)=\big[\cos(2\pi\ \{$ ميزات $\text{}$ فوريه:	(3.4.54)	54
$\lambda_k\dots t\},\qquad e^{-\lambda_k f^{\star}(k)\|\sim f_t(k)-\hat\ \|\hat\ \{$ NTK: التحيّز $\text{}$ الطيفي عبر	(4.4.54)	54
$y)\big]\ y\{(\hat p_{\hat E\big[-\log_2 x)\big]+\lambda\,\mathbb E\big[d(x,\hat \mathbb \min_{\theta,\phi}\$	(1.5.54)	54
$D=\dots\ y\],\quad p_{\hat E[-\log_2 R=\mathbb y),\qquad x=D_\phi(\hat \hat y=Q\big(E_\theta(x)\big),\qquad \hat$	(2.5.54)	54
$\quad\text{}$ والمساواة $I(x;\hat y)\ge H(\hat R\ge\ \{$ حدّ $\text{}$ معلوماتي: $y)$ بترميز مثالي	(3.5.54)	54
$lambda=-\frac{dR}{dD}$، و $\}$ محدّب متناقص، $R(D)\text{}\ \{$ منحنى $\text{}$ المعدّل-التشويه:	(4.5.54)	54
$ijk/N\|\|k\rangle N\}\sum_{k=0}^{N-1}e^{2\pi \mathrm{QFT}\|j\rangle=\frac{1}{\sqrt$	(1.6.54)	54
$\text{}$ كلاسيكياً $N)\text{}\ \{O(N\log$ بوابة مقابل $O(\log^{2}N)\text{}\ \}\ \text{}$ التكلفة:	(2.6.54)	54
$\dots$ بدقة $i\theta\|\|u\rangle\text{}\ \{U\|u\rangle=e^{2\pi}$ من $\theta\text{}\ \text{}\ \}$ يستخرج (QPE) تقدير $\text{}$ الطور:	(3.6.54)	54
$(\text{}$ مكلّف $\|x\rangle=\frac{1}{\|x\|}\sum_i$ الحالة: $\ \}$ تحضير $\text{}\ x_i\|i\rangle\quad$ — عنق زجاجة $)$	(4.6.54)	54
$I(t_{\text{}$آخر$}})\|>C\ I(t)-\log\ \|\log \text{}$ عند $p=\pm1\ e=(x,y,t,p),\quad \}\ \text{}$ حدث:	(1.7.54)	54
$\text{}$ حدة التباين $\lambda_e\propto\text{}$ الحركة $\cdot\text{}$ الحرارة $\ \}$ مقدار $\text{}$ الأحداث: معدّل	(2.7.54)	54
$\dots\ V_{\text{th}}\ \{V\ge \text{}$ عند $s=1\ V_{t-1}+\sum_jw_js_j(t),\quad V_t=\beta\ \}\ \text{}$ (تكامل وتفريغ): SNN	(3.7.54)	54
$\text{}$ تنطبق $\dots\ x_n\,\mathrm{sinc}\!\left(\frac{t-t_n}{T}\right)\ x(t)=\sum_n\ \{$ غير المنتظمة: $\text{}$ العيّنات	(4.7.54)	54
$T\dots\ \mathcal T(x)\big)\Big),\qquad T^{-1}\Big(g_\theta\big(\mathcal y=\mathcal\ \{$ الموحّد: $\text{}$ النمط	(1.8.54)	54
$n}_{\text{}$سعة $+\dots\ H)/\sqrt C(\mathcal R+\underbrace{\mathcal E[R]\le\hat\ \mathbb\ \{$ تعميم طيفي: $\text{}$ حدّ	(2.8.54)	54
$\varepsilon\approx\underbrace{\sum_{k>K}\|c_k\|^{2}}_{\text{}$اقتطاع $+\dots\}$ التمثيل: $\text{}$ ميزانية	(3.8.54)	54
$\dots$ على $\text{}$ مويجات، متقطّع $\Rightarrow$ فوريه، متصل $\Rightarrow$ دوري $\text{}$ بحسب بنية الإشارة: $T\text{}\ \{\mathcal\ \text{}$ اختر $\}\ \text{}$ التصميم: $\text{}$ قاعدة	(4.8.54)	54

الجزء الأول: الأسس الرياضية

الفصل	الوصف	الملف
01	قوانين دي مورغان	figures/fig-0101-demorgan.svg
01	مبدأ الشمول والاستبعاد	figures/fig-0102-inclusion-exclusion.svg
01	الاستقراء الرياضي	figures/fig-0103-induction.svg
01	مبدأ الحمام	figures/fig-0104-pigeonhole.svg
01	قواعد الاستدلال	figures/fig-0105-inference.svg
02	الفضاء المتجهي والأساس	figures/fig-0201-vector-space-basis.svg
02	كوشي–شفارتس ومتراجحة المثلث	figures/fig-0202-cauchy-schwarz.svg
02	الإسقاط المتعامد	figures/fig-0203-orthogonal-projection.svg
02	غرام–شميدت	figures/fig-0204-gram-schmidt.svg
02	الرتبة والعدمية	figures/fig-0205-rank-nullity.svg
03	المصفوفة كتحويل خطي	figures/fig-0301-linear-transformation.svg
03	المحدّد ومساحة	figures/fig-0302-determinant-area.svg
03	الآثر والمحدّد	figures/fig-0302-determinant-area.svg
03	وودبري	figures/fig-0305-woodbury-update.svg

03	التفكك القطبي	figures/fig-0304-polar-decomposition.svg
04	المتجهات الذاتية هي الاتجاهات الثابتة للتحويل: دائرة الوحدة تتحول إلى قطع ناقص أنصاف محاوره |λ₁| و |λ₂|	figures/fig-0401-eigen-directions.svg
04	SVD: تدوير ثم تمديد ثم تدوير — دائرة الوحدة تمرّ بأربع مراحل لتصبح قطعاً ناقصاً	figures/fig-0402-svd-geometry.svg
04	نظرية إيكارت–يونغ: اقتطاع القيم المفردة عند الرتبة k يعطي أفضل تقريب من رتبة k	figures/fig-0403-eckart-young.svg
04	خارج قسمة رايلي محصور بين λ_min و λ_max، ومتراجحة فايل تحدّد نطاق تغير القيم الذاتية	figures/fig-0404-rayleigh-quotient.svg
04	متجه فيدلر للابلاس الرسم يقسّم الرسم بأقل تكلفة قطع	figures/fig-0405-graph-laplacian-fiedler.svg
04	نظرية بيرون–فروبينيوس: المتجه الذاتي الموجب الوحيد هو توزيع PageRank المستقر	figures/fig-0406-perron-frobenius.svg
05	متراجحة كوشي–شفارتس هندسياً: الإسقاط والزاوية	figures/fig-0502-cauchy-schwarz.svg
05	الناظم الثنوي: مستوى داعم يمسّ كرة الوحدة	figures/fig-0503-dual-norm.svg
05	كرات الوحدة لنواظم p وتداخلها	figures/fig-0501-norm-unit-balls.svg
05	الناظم المستحث هندسياً: دائرة الوحدة إلى قطع ناقص	figures/fig-0504-operator-norm.svg
05	متراجحة فون نيومان للأثر وإعادة الترتيب	figures/fig-0505-von-neumann-trace.svg
05	لمّة جونسون–ليندنشتراوس: إسقاط عشوائي يحفظ المسافات	figures/fig-0506-johnson-lindenstrauss.svg
06	رقم الحالة يضخّم كرة الخطأ من الإدخال إلى المخرج	figures/fig-0601-conditioning.svg
06	الإلغاء الكارثي: مجالا تقريب لعددين متقاربين وفرقهما الصغير، وتراكم خطأ الجمع	figures/fig-0602-cancellation.svg
06	انعكاس هاوسهولدر يصفّر عموداً كاملاً، والاستقرار الخلفي لـ QR	figures/fig-0603-householder-qr.svg
06	هندسة المربعات الصغرى: الباقي عمودي على مجال A، والزاوية θ تتحكّم بحدّ كابا تربيع	figures/fig-0604-least-squares-conditioning.svg
06	عامل النموّ في LU والتنقيح التكراري: من مصفوفة إلى U متضخّمة، ثم تصحيح الباقي	figures/fig-0605-lu-growth-factor.svg
06	استقرار softmax: منحنى exp وعتبات الفيضان، والإزاحة بمقدار m	figures/fig-0606-logsumexp-stability.svg

الجزء الثاني: التفاضل والتكامل

الفصل	الوصف	الملف
07	تعريف ϵ–δ للنهاية	figures/fig-0701-epsilon-delta.svg
07	أنواع الانقطاع الأربعة	figures/fig-0702-discontinuities.svg
07	تقارب نقطي مقابل موحّد	figures/fig-0703-pointwise-vs-unfiorm.svg
08	المشتقّ كميل مماس	figures/fig-0801-derivative-as-slope.svg
08	قاعدة السلسلة	figures/fig-0802-chain-rule.svg
08	رول والقيمة الوسطى	figures/fig-0803-rolle-mvt.svg
09	اليعقوبية كحصاد الحساسيات	figures/fig-0901-jacobian.svg
09	الهسّية تصنّف النقطة الحرجة	figures/fig-0902-hessian.svg
10	سيغما-جبرا كأصغر عائلة مغلقة تحت المتمّم والاتحاد	figures/fig-1001-sigma-algebra.svg
10	ريمان يقسّم المجال، ليبيسغ يقسّم المدى	figures/fig-1002-lebesgue-measure.svg
10	الدالة القياسية: صورة كل بوريل عكسياً قياسية	figures/fig-1003-measurable-function.svg
10	التكامل كحدّ لأعلى دوالّ بسيطة	figures/fig-1004-mct.svg
10	التقارب المرافق: تسلسل محصور بين ±g	figures/fig-1005-dct.svg
10	تكامل ستيلتjes ككُتل عند قفزات CDF	figures/fig-1006-lebesgue-stieltjes.svg
11	متعدّدات تايلور من الدرجات 1 و2 و3	figures/fig-1101-taylor-polynomial.svg
11	البقايا كالمنطقة بين f و P_n	figures/fig-1102-remainder-lagrange.svg
11	التقريب التربيعي وحوض الهسّية	figures/fig-1103-multivariate-hessian.svg
11	انخفاض خطأ القطع مع الدرجة	figures/fig-1104-truncation-error.svg
11	انتشار الخطأ عبر f	figures/fig-1105-error-propagation.svg
11	خطوة نيوتن على منحنى محدّب	figures/fig-1106-newton-step.svg
12	حقل اتجاهات ومسار حلّ	figures/fig-1201-ode-direction-field.svg
12	خطوات أويلر والميل المحلي	figures/fig-1202-euler-method.svg
12	مخطّط طور بأنواع النقاط الثابتة	figures/fig-1203-phase-portrait.svg
12	معادلة الحرارة تنعّم إشارة	figures/fig-1204-dffiusion-pde.svg
12	تدفّق تدرّجي هابط	figures/fig-1205-gradient-flow.svg
12	مسار الانتشار العكسي من الضجيج للبيانات	figures/fig-1206-dffiusion-trajectory.svg

الجزء الثالث: الاحتمال والإحصاء

الفصل	الوصف	الملف
13	فضاء الاحتمال Ω مع أحداث ونِسَب	figures/fig-1301-probability-space.svg
13	المتغيّر العشوائي كدالة قياسية وقياس مدفوع	figures/fig-1302-random-variable.svg

figures/fig-1303-cdf-pmf-pdf.svg	CDF منفصل مقابل سلس و PDF	13
figures/fig-1304-conditional-independence.svg	الاحتمال الشرطي والاستقلال	13
figures/fig-1305-expectation-integral.svg	التوقّع كمساحة تحت الكثافة	13
figures/fig-1306-convergence-modes.svg	تضمينات أنماط التقارب	13
figures/fig-1401-discrete-distributions.svg	توزيعات منفصلة قياسية	14
figures/fig-1402-continuous-distributions.svg	توزيعات مستمرة قياسية	14
figures/fig-1403-joint-marginal.svg	توزيع مشترك وتهميش	14
figures/fig-1404-change-of-variables.svg	تغيير المتغيرات والجاكوبي	14
figures/fig-1405-multivariate-normal.svg	توزيع غاوسي متعدد المتغيرات	14
figures/fig-1406-mgf-characteristic.svg	الدوال المولّدة للحظات والمميّزة	14
figures/fig-1501-expectation.svg	المتوقّع كمركز كتلة	15
figures/fig-1502-variance.svg	التباين كانتشار	15
figures/fig-1503-inequalities.svg	متراجحات الذيل	15
figures/fig-1504-psd-cone.svg	المصفوفة الموجبة نصف التحديد	15
figures/fig-1505-schur-complement.svg	المكمّل الشورّي	15
figures/fig-1506-fisher-information.svg	معلومات فيشر وكرامير-راو	15
figures/fig-1601-bayes-theorem.svg	نظرية بايز	16
figures/fig-1602-bayesian-update.svg	تحديث بايزي	16
figures/fig-1603-conjugate-priors.svg	العائلات المترافقة	16
figures/fig-1604-naive-bayes.svg	بايز الساذج	16
figures/fig-1605-bayesian-network.svg	شبكة بايزية	16
figures/fig-1606-markov-chain.svg	سلسلة ماركوف	16
figures/fig-1607-mrf-crf.svg	حقل عشوائي ماركوف	16
figures/fig-1701-markov.svg	متراجحة ماركوف: مساحة الذيل فوق a محصورة بالمتوقع	17
figures/fig-1702-chebyshev.svg	متراجحة تشيبيشيف: الذيلان محصوران بالتباين على t مربع	17
figures/fig-1703-chernoff.svg	متراجحة تشيرنوف: الإمالة الأسّية تضيّق الذيل	17
figures/fig-1704-hoeffding.svg	متراجحة هافدينغ: التضاؤل الأسّي للانحراف مع n	17
figures/fig-1705-bernstein.svg	متراجحة برنشتاين: أفضل من هافدينغ عند تباين صغير	17
figures/fig-1706-martingale.svg	مسيرة أزوما: خطوات مقيدة تحصر الانحراف	17
figures/fig-1707-kl-chernoff.svg	متراجحة KL: التباعد يقيس انحناء القيد	17
figures/fig-1801-mle.svg	تقدير الاحتمال الأقصى: قمّة دالة الاحتمال	18
figures/fig-1802-map.svg	تقدير بايز الأقصى: دمج السابق مع الاحتمال	18
figures/fig-1803-estimator-properties.svg	خصائص المقدّر: التحيّز والتباين وMSE	18
figures/fig-1804-bayesian-estimator.svg	المقدّر البايزي: الوسط الخلفي	18
figures/fig-1805-confidence-interval.svg	فترة الثقة: تقدير ± هامش	18
figures/fig-1806-hypothesis-testing.svg	اختبار الفرضيات: منطقتا القبول والرفض	18
figures/fig-1807-em-algorithm.svg	خوارزمية EM: صعود رتيب في الاحتمال	18
figures/fig-1901-stationarity-acf.svg	الثبات ودالة الارتباط الذاتي	19
figures/fig-1902-ar-process.svg	نموذج الانحدار الذاتي AR	19
figures/fig-1903-arma.svg	نماذج MA و ARMA	19
figures/fig-1904-random-walk-arima.svg	المشي العشوائي التفاضل وARIMA	19
figures/fig-1905-poisson-process.svg	عملية بواسون: وصول أحداث بمعدل لامدا	19
figures/fig-1906-brownian-motion.svg	الحركة البراونية ومسارات وينر	19
figures/fig-1907-martingale.svg	المارتنغيال والتوقف الاختياري	19

الجزء الرابع: التحسين

الفصل	الوصف	الملف
20	شرط الرتبة الأولى: التدرج يصفر عند الأمثلية	figures/fig-2001-first-order-stationarity.svg
20	شروط الرتبة الثانية: الهسية تحدد النوع	figures/fig-2002-second-order-hessian.svg
20	التحدب: المستقيم فوق المنحنى والأمثلية العالمية	figures/fig-2003-convexity.svg
20	السلاسة والتحدب القوي ورقم الحالة	figures/fig-2004-strong-convexity-conditioning.svg
20	البحث الخطي: شروط أرميخو وولف	figures/fig-2005-line-search.svg
20	معدلات تقارب هبوط التدرج	figures/fig-2006-gradient-descent-rates.svg
20	نيوتن مقابل هبوط التدرج	figures/fig-2007-newton-quasi-newton.svg
21	مضاعفات لاغرانج: تماس منحنيات المستوى مع سطح القيد	figures/fig-2101-lagrange-multiplier.svg
21	شروط KKT الأربعة	figures/fig-2102-kkt-conditions.svg
21	الثنائية اللاغرانجية: التقليل الداخلي والتعظيم الخارجي	figures/fig-2103-lagrangian-duality.svg
21	الثنائية الضعيفة والقوية وفجوة الثنائية	figures/fig-2104-weak-strong-duality.svg
21	الإسقاط على مجموعة محدبة والتدرج المسقوط	figures/fig-2105-projection.svg
21	طريقة العقوبة ولاغرانج المعزز	figures/fig-2106-penalty-augmented.svg
21	SVM: الهامش وقيود التصنيف	figures/fig-2107-svm-margin-constraints.svg

22	المجموعات المحدبة ونظرية الفصل	figures/fig-2201-convex-sets-separation.svg
22	الدوال المحدبة والعمليات الحافظة للتحدب	figures/fig-2202-convex-functions-operations.svg
22	التدرج الجزئي لدالة غير سلسة	figures/fig-2203-subgradient.svg
22	الازدواج المترافق فنشل	figures/fig-2204-fenchel-conjugate.svg
22	ازدواج فنشل روكافلر	figures/fig-2205-fenchel-rockafellar-duality.svg
22	المؤثر القريب وخوارزمية النزول القريب	figures/fig-2206-proximal-operator-ista.svg
22	تسريع FISTA ومعدل التقارب	figures/fig-2207-fista-acceleration.svg
23	الهبوط العشوائي SGD	figures/fig-2301-stochastic-gradient-descent.svg
23	الزخم الثقيل: كرة تتدحرج في واد	figures/fig-2302-heavy-ball-momentum.svg
23	تسريع نيستروف: القياس في نقطة مستبقة	figures/fig-2303-nesterov-acceleration.svg
23	الطرق التكيفية AdaGrad و RMSProp	figures/fig-2304-adagrad-rmsprop.svg
23	Adam و AdamW	figures/fig-2305-adam-adamw.svg
23	تقليل التباين SVRG و SAGA	figures/fig-2306-variance-reduction.svg
23	جدولة معدل التعلم: التسخين وجيب التمام	figures/fig-2307-learning-rate-schedules.svg
24	فضاء المماس والتدرج الريماني	figures/fig-2401-tangent-space-riemannian-gradient.svg
24	الانكماش ونقل المتجه على متشعب	figures/fig-2402-retraction-vector-transport.svg
24	الهبوط التدريجي الريماني	figures/fig-2403-riemannian-gradient-descent.svg
24	الهسية الريمانية ونيوتن الريماني	figures/fig-2404-riemannian-hessian-newton.svg
24	متشعب الكرة والاتجاهات الوحيدة	figures/fig-2405-sphere-manfiold.svg
24	متشعب شتيفل والقيود المتعامدة	figures/fig-2406-stiefel-orthogonality.svg
24	متشعب الرتبة الثابتة ومصفوفات موجبة التحديد	figures/fig-2407-fixed-rank-psd-manfiolds.svg
25	التحسين الأسود: صندوق بلا تدرج	figures/fig-2501-blackbox-optimization.svg
25	العمليات الغاوسية كنموذج بديل	figures/fig-2502-gaussian-process-surrogate.svg
25	دالة الاكتساب: التحسين المتوقع	figures/fig-2503-expected-improvement.svg
25	UCB و PI ومقايضة الاستكشاف والاستغلال	figures/fig-2504-ucb-pi-exploration.svg
25	الندم التراكمي وإطار bandits	figures/fig-2505-regret-bandits.svg
25	التحسين التوزيعي: توازي البيانات ومعلم العاملات	figures/fig-2506-distributed-optimization.svg
25	متوسط النماذج والتعلم الاتحادي	figures/fig-2507-federated-model-averaging.svg

الجزء الخامس: نظرية المعلومات

الفصل	الوصف	الملف
26	إنتروبيا شانون: أقصى قيمة عند التوزيع المنتظم	figures/fig-2601-shannon-entropy.svg
26	الإنتروبيا المشتركة والشرطية	figures/fig-2602-joint-conditional-entropy.svg
26	المعلومات المتبادلة كتقاطع	figures/fig-2603-mutual-information.svg
26	خصائص الإنتروبيا: التقعر والحد الأقصى	figures/fig-2604-entropy-properties.svg
26	الإنتروبيا التفاضلية للمتغيرات المستمرة	figures/fig-2605-dffierential-entropy.svg
26	كسب المعلومات في أشجار القرار	figures/fig-2606-information-gain-tree.svg
26	مبدأ الإنتروبيا الأعظمية والتوزيعات الأسية	figures/fig-2607-maximum-entropy.svg
27	إنتروبيا التقاطع: إنتروبيا الحقيقة زائد تباعد KL	figures/fig-2701-cross-entropy.svg
27	تباعد KL: غير متماثل وبعدين	figures/fig-2702-kl-divergence.svg
27	خصائص KL: جيبس عدم التماثل ومعالجة البيانات	figures/fig-2703-kl-properties.svg
27	تباعدات ف-ديفرجنس: عائلة المولدات	figures/fig-2704-f-divergences.svg
27	الحدود التباينية لتقدير KL في بعد عال	figures/fig-2705-variational-bounds.svg
27	خسارة الإنتروبيا المتقاطعة مع softmax	figures/fig-2706-cross-entropy-loss.svg
27	مقارنة تباعدات JS و TV و Hellinger و Wasserstein	figures/fig-2707-divergence-comparison.svg
28	الترميز المصدري: مجموعة النماذج	figures/fig-2801-source-coding-typical-set.svg
28	سعة القناة: أقصى معدل موثوق	figures/fig-2802-channel-capacity.svg
28	ترميز هافمان: شجرة الدمج	figures/fig-2803-huffman-tree.svg
28	الترميز الحسابي: فترات متداخلة	figures/fig-2804-arithmetic-coding.svg
28	متراجحة كرافت: شجرة البتّات	figures/fig-2805-kraft-inequality.svg
28	معدل-تشويه: التخلي عن الدقة مقابل البتات	figures/fig-2806-rate-distortion.svg
28	مبدأ الوصف الأقصر: وصف النموذج زائد وصف البيانات	figures/fig-2807-mdl-description-length.svg
29	فضاء التوزيعات كمتشعّب تفاضلي	figures/fig-2901-statistical-manfiold.svg
29	KL بوصفه نصف مربع طول فيشر	figures/fig-2902-fisher-metric-kl.svg
29	متراجحة كرامير-راو	figures/fig-2903-cramer-rao.svg
29	التدرج الطبيعي مقابل التدرج العادي	figures/fig-2904-natural-gradient.svg
29	البنية المزدوجة وإسقاطات فيثاغورس	figures/fig-2905-dual-coordinates-em.svg
29	جيوديسيات فيشر-راو	figures/fig-2906-fisher-rao-geodesics.svg
29	EM كإسقاطات متعاقبة	figures/fig-2907-em-algorithm-projections.svg

الجزء السادس: نظرية التعلّم الإحصائي

الفصل	الوصف	الملف
30	إطار التعلم الإحصائي	figures/fig-3001-learning-framework.svg
30	مبدأ تقليل الخطر البنيوي	figures/fig-3002-srm-bound.svg
30	لوحة السهام للتحيز والتباين	figures/fig-3003-bias-variance-dartboard.svg
30	منحنيات التحيز والتباين	figures/fig-3004-bias-variance-curves.svg
30	هندسة L1 مقابل L2	figures/fig-3005-regularization-geometry.svg
30	التحقق المتقاطع ذو الخمسة أضعاف	figures/fig-3006-cross-validation.svg
30	تفكيك الخطر الزائد إلى ثلاثة مصادر	figures/fig-3007-three-errors.svg
31	التحطيم وبعد VC	figures/fig-3101-shattering.svg
31	بعد VC للمستطيلات المحورية	figures/fig-3102-vc-dimension.svg
31	متراجحة Sauer ودالة النمو	figures/fig-3103-sauer-growth.svg
31	متراجحة VC وتعقيد العينة	figures/fig-3104-vc-inequality.svg
31	تعقيد Rademacher	figures/fig-3105-rademacher.svg
31	أرقام التغطية	figures/fig-3106-covering-numbers.svg
31	حدود الهامش	figures/fig-3107-margin-bound.svg
32	إطار PAC	figures/fig-3201-pac-framework.svg
32	مبرهنة التأسيس لـ PAC	figures/fig-3202-fundamental-theorem.svg
32	التعلم غير المتحيز	figures/fig-3203-agnostic-pac.svg
32	الحدود السفلى لتعقيد العينة	figures/fig-3204-lower-bounds.svg
32	تعقيد العينة لفئات محددة	figures/fig-3205-sample-complexity-classes.svg
32	التعزيز من الضعيف إلى القوي	figures/fig-3206-boosting-weak-strong.svg
32	التعقيد الحسابي للتعلم	figures/fig-3207-computational-hardness.svg
33	تبديل نقطة تدريب واحدة وقياس التغير في الخسارة	figures/fig-3301-stability-swap.svg
33	التحدب القوي يقيد حركة النقطة الصغرى عند تبديل مثال واحد	figures/fig-3303-strong-convexity-stability.svg
33	تباعد مساري هبوط التدرج العشوائي مع عدد الخطوات	figures/fig-3304-sgd-stability-trajectory.svg
33	مقدر اترك واحدا خارجا وعلاقته بالاستقرار	figures/fig-3305-cross-validation-stability.svg
33	مقبضات الاستقرار في الخوارزميات التكرارية	figures/fig-3306-iterative-stability-knobs.svg
33	التدرج العشوائي ذو الخصوصية التفاضلية ومقارنة حدود السعة بالاستقرار	figures/fig-3307-dp-stability-deep-nets.svg
33	حد الاستقرار بدلالة ثابت الاستقرار مقابل حدود السعة	figures/fig-3302-stability-bound.svg
34	مفارقة المعلمات الزائدة وذروة التعميم	figures/fig-3401-overparam-paradox.svg
34	الحد المعياري بدلالة حاصل ضرب المعايير الطيفية والهامش	figures/fig-3402-norm-margin-bound.svg
34	حد باك-بايز بدلالة تباعد كي-إل وحجم العينة	figures/fig-3403-pac-bayes-kl.svg
34	حد الضغط بدلالة عدد المعلمات المضغوطة والبتات	figures/fig-3404-compression-bound.svg
34	الانحياز الضمني لهبوط التدرج نحو أقصى هامش	figures/fig-3405-implicit-bias-margin.svg
34	منحنى الهبوط المزدوج ونقطة الاستيعاب	figures/fig-3406-double-descent.svg
34	ديناميكا نواة التماس العصبية ونظام التدريب الكسول	figures/fig-3407-ntk-kernel-dynamics.svg

الجزء السابع: رياضيات الشبكات العصبية

الفصل	الوصف	الملف
35	البيرسيبترون ومستوي الفصل	figures/fig-3501-perceptron.svg
35	معمارية الشبكة الأمامية	figures/fig-3502-feedforward-architecture.svg
35	دوال التنشيط	figures/fig-3503-activations.svg
35	التقريب الشامل بطبقة واحدة	figures/fig-3504-uat-single-hidden.svg
35	التقريب المحدود بالعرض	figures/fig-3505-width-bounded.svg
35	معدّل تقارب بارون	figures/fig-3506-barron-rate.svg
35	فصل العمق	figures/fig-3507-depth-separation.svg
36	الرسم الحسابي	figures/fig-3601-computational-graph.svg
36	تدرّج المصفوفة	figures/fig-3602-jacobian.svg
36	تنشيط عنصري	figures/fig-3603-elementwise.svg
36	تعقيد التفاضل العكسي	figures/fig-3604-reverse-mode-cost.svg
36	softmax والإنتروبيا	figures/fig-3605-softmax-ce.svg
36	تلاشي وانفجار التدرّج	figures/fig-3606-vanishing-gradient.svg
36	فحص التدرّج	figures/fig-3607-gradient-check.svg
37	عملية الالتفاف	figures/fig-3701-convolution-op.svg
37	الاتصال المحلي ومشاركة الأوزان	figures/fig-3702-local-connectivity.svg
37	التماثل الترجمي	figures/fig-3703-translation-equivariance.svg
37	التجميع	figures/fig-3704-pooling.svg

الفصل	الوصف	الملف
37	الحقل الاستقبالي	figures/fig-3705-receptive-field.svg
37	الانتشار العكسي للالتفاف	figures/fig-3706-backprop-conv.svg
37	متغيّرات الكفاءة	figures/fig-3707-efficiency-variants.svg
38	الخلية المتكررة	figures/fig-3801-recurrent-cell.svg
38	BPTT	figures/fig-3802-bptt.svg
38	التلاشي والانفجار	figures/fig-3803-vanishing-exploding.svg
38	خلية LSTM	figures/fig-3804-lstm.svg
38	خلية GRU	figures/fig-3805-gru.svg
38	seq2seq	figures/fig-3806-seq2seq.svg
38	التضمين	figures/fig-3807-embedding.svg
39	الانتباه المقاس	figures/fig-3901-scaled-attention.svg
39	تعدد الرؤوس	figures/fig-3902-multihead.svg
39	الترميز الموضعي	figures/fig-3903-positional-encoding.svg
39	كتلة المحوّل	figures/fig-3904-transformer-block.svg
39	القناع	figures/fig-3906-masking.svg
39	المشفّر-فك التشفير	figures/fig-3905-encoder-decoder.svg
39	الانتباه الفعال	figures/fig-3907-efficient-attention.svg
40	مفهوم NTK	figures/fig-4001-ntk-concept.svg
40	ديناميكا التدريب	figures/fig-4002-training-dynamics.svg
40	توسّع العرض	figures/fig-4005-width-scaling.svg
40	انحدار النواة	figures/fig-4003-kernel-regression.svg
40	NNGP مقابل NTK	figures/fig-4004-nngp-vs-ntk.svg
40	النواة الالتفافية	figures/fig-4006-conv-ntk.svg
40	النواة مقابل الميزات	figures/fig-4007-kernel-vs-feature.svg
41	بنية VAE	figures/fig-4101-vae-architecture.svg
41	لعبة GAN	figures/fig-4102-gan-minimax.svg
41	التدفّقات التطبيعيّة	figures/fig-4103-normalizing-flow.svg
41	الانتشار الأماميّ	figures/fig-4104-dffiusion-forward.svg
41	الانتشار العكسي	figures/fig-4105-dffiusion-reverse.svg
41	نموذج السكور والSDE	figures/fig-4106-score-sde.svg
41	قياس جودة التوليد	figures/fig-4107-evaluation-fid.svg
42	صياغة كانتوروفيتش	figures/fig-4201-kantorovich-transport.svg
42	ثنائية KR	figures/fig-4202-wasserstein-duality.svg
42	الانتظام الإنتروبي	figures/fig-4203-entropic-ot-sinkhorn.svg
42	ناقد WGAN	figures/fig-4204-wgan-critic.svg
42	خريطة Brenier	figures/fig-4205-brenier-map.svg
42	تدفّق JKO	figures/fig-4206-jko-flow.svg
42	تباعد Sinkhorn المصحّح	figures/fig-4207-sinkhorn-divergence.svg

الجزء الثامن: بنى متقدّمة

الفصل	الوصف	الملف
43	تمثيل الرسوم	figures/fig-4301-graph-adjacency.svg
43	طيف اللابلاسي	figures/fig-4302-laplacian-spectrum.svg
43	التجميع الطيفي	figures/fig-4303-spectral-clustering.svg
43	GCN	figures/fig-4304-gcn-message-passing.svg
43	ثبات التبديل	figures/fig-4305-permutation-equivariance.svg
43	اختبار WL	figures/fig-4306-wl-test.svg
43	GAT	figures/fig-4307-graph-attention.svg
44	حلقة MDP	figures/fig-4401-mdp-loop.svg
44	نسخة بيلمان الاحتياطيّة	figures/fig-4402-bellman-backup.svg
44	تكرار القيمة/السياسة	figures/fig-4403-value-policy-iteration.svg
44	Q-learning	figures/fig-4404-q-learning.svg
44	تدرّج السياسة	figures/fig-4405-policy-gradient.svg
44	استكشاف واستغلال	figures/fig-4406-exploration-exploitation.svg
44	الممثّل والناقد	figures/fig-4407-actor-critic.svg
45	مصفوفة اللعبة	figures/fig-4501-normal-form-matrix.svg
45	توازن ناش	figures/fig-4502-nash-equilibrium.svg
45	ثنائيّة الصفر	figures/fig-4503-zero-sum-minimax.svg
45	اللعب الوهميّ	figures/fig-4504-fictitious-play.svg
45	CFR والندامة	figures/fig-4505-cfr-regret.svg
45	لعبة إمكان	figures/fig-4506-potential-game.svg
45	تعلّم متعدّد الوكلاء	figures/fig-4507-multi-agent-seflplay.svg
46	المُبسّطات	figures/fig-4601-simplicial-complex.svg

figures/fig-4602-homology-betti.svg	التجان وأرقام بيتّي	46
figures/fig-4603-persistent-homology.svg	التجانس الدائم	46
figures/fig-4604-stability-theorem.svg	نظريّة الثبات	46
figures/fig-4605-vietoris-rips-cech.svg	ريبس وČech	46
figures/fig-4606-mapper.svg	مخطّط	46
figures/fig-4607-tda-ml-features.svg	TDA للتعلّم	46
figures/fig-4701-category-basics.svg	الفئة والتركيب	47
figures/fig-4703-universal-adjunction.svg	الخصائص العالميّة	47
figures/fig-4704-monoidal-string.svg	مونيّد وشريطيّ	47
figures/fig-4705-monad.svg	المونّاد	47
figures/fig-4706-lens-optic.svg	العدسة والبصريّة	47
figures/fig-4702-functor-natural-transformation.svg	قاعدة بيانات فئويّة	47
figures/fig-4707-backprop-as-optic.svg	النشر العكسي كبصريّات	47
figures/fig-4801-manfiold-tangent-space.svg	المتشعّب والفضاء المماسيّ	48
figures/fig-4802-riemannian-geodesic.svg	الجيوديسيّات	48
figures/fig-4803-parallel-transport-holonomy.svg	النقل المتوازي	48
figures/fig-4804-curvature-types.svg	أنواع الانحناء	48
figures/fig-4805-natural-gradient.svg	التدرّج الطبيعي	48
figures/fig-4806-manfiold-learning.svg	التعلّم على المتشعّب	48
figures/fig-4807-statistical-manfiold.svg	الهندسة الإحصائيّة	48

الجزء التاسع: المتسلسلات ومعالجة الإشارة

الفصل	الوصف	الملف
49	شجرة معايير تقارب المتسلسلات الموجبة: المقارنة، النسبة، الجذر، والمعايير الاحتياطية عند L=1	figures/fig-4901-convergence-tests.svg
49	التقارب المطلق مقابل الشرطي: تأثير إعادة الترتيب على المجموع	figures/fig-4902-conditional-absolute.svg
49	متسلسلة القوى ونصف قطر التقارب في المستوي المركب	figures/fig-4903-power-series-radius.svg
49	التقارب الموحد: أنبوب إبسلون حول دالة النهاية يحصر كل المجاميع الجزئية	figures/fig-4904-unfiorm-convergence.svg
49	من العلاقة التكرارية إلى الدالة المولدة إلى الشكل المغلق ثم استخراج المعاملات	figures/fig-4905-generating-function.svg
49	ترويض متسلسلة متذبذبة بمتوسطات سيزارو وتجميع أبيل	figures/fig-4906-cesaro-abel.svg
49	متفاوتة بيسل ومساواة بارسيفال: توزيع طاقة الإشارة على المكونات العمودية	figures/fig-4907-orthogonal-expansion.svg
50	عمودية الدوال المثلثية: تكامل الجداء يصفّر للترددات المختلفة	figures/fig-5001-fourier-orthogonality.svg
50	تقارب ديريكله النقطي: عند نقطة الاستمرار إلى قيمة الدالة وعند القفزة إلى نصف المجموع	figures/fig-5003-dirichlet-convergence.svg
50	ظاهرة غيبس: تجاوز دائم بنحو 9% من سعة القفزة لا يزول بزيادة الحدود	figures/fig-5004-gibbs-phenomenon.svg
50	خطأ الاقتطاع وذيل الطيف: العلاقة بين عدد المعاملات المحفوظة والخطأ	figures/fig-5006-truncation-error.svg
50	مقارنة نواة ديريكله المتذبذبة بنواة فيير الموجبة وأثرهما على التقارب	figures/fig-5005-fejer-kernel.svg
50	فوريه المركب: المعاملات على دائرة الوحدة والتماثل الهيرميتي للإشارات الحقيقية	figures/fig-5007-complex-fourier.svg
50	من الدالة إلى معاملات فوريه ثم إعادة التركيب بعد الاقتطاع	figures/fig-5002-fourier-coefficients.svg
51	تحويل فوريه المتصل: الإشارة في الزمن وطيفها في التردد	figures/fig-5101-fourier-transform-pair.svg
51	DFT ومصفوفة جذور الوحدة وخوارزمية FFT	figures/fig-5102-dft-matrix.svg
51	نظرية نيكويست-شانون: شرط معدل العينات وإعادة البناء بنواة sinc	figures/fig-5103-sampling-nyquist.svg
51	التشويه الطيفي: عينات إشارة عالية التردد توافق إشارة منخفضة التردد	figures/fig-5104-aliasing.svg
51	مبرهنة الالتفاف: الترشيح ضرب في مجال التردد	figures/fig-5105-convolution-theorem.svg
51	طيف القدرة والارتباط الذاتي بحسب فينر-خينتشين	figures/fig-5107-psd-autocorr.svg
52	مبدأ الريبة: العلاقة العكسية بين دقة الزمن ودقة التردد	figures/fig-5201-uncertainty-principle.svg
52	STFT: شبكة زمن-تردد بدقة ثابتة تنتج المخطوط الطيفي	figures/fig-5202-stft-spectrogram.svg
52	المويجات: تبليط متعدد المقاييس لمربع الزمن-التردد	figures/fig-5203-wavelet-scaling.svg
52	DWT: بنك مرشحات التحليل وإعادة التركيب مع تقليل العينات	figures/fig-5204-dwt-filterbank.svg
52	إزالة الضجيج بعتبة المعاملات المويجية	figures/fig-5205-wavelet-denoising.svg
52	توزيع فيغنر-فيل وظهور الحدود المتقاطعة بين مكونين	figures/fig-5206-wigner-ville.svg
52	تحويل التشتت: تمثيل هرمي ثابت للترجمة بلا معاملات متعلمة	figures/fig-5207-scattering-transform.svg
53	مقارنة بنيتي FIR وIIR من حيث التلقيم الراجع والاستقرار والأقطاب	figures/fig-5301-fir-iir-filters.svg
53	الالتفاف الموسع: توسيعات هندسية تعطي حقلا استقباليا أسيا	figures/fig-5303-dilated-convolutions.svg
53	تعقيد الانتباه التربيعي وبدائله من النوافذ إلى المزج الطيفي	figures/fig-5304-attention-complexity.svg
53	نماذج الحالة: مواقع الأقطاب تحدد طول الذاكرة وتهيئة HiPPO	figures/fig-5305-ssm-spectral.svg
53	المُرمِّز الصوتي العصبي: من الطيف إلى الموجة عبر شبكة توليدية	figures/fig-5306-neural-vocoder.svg
53	تكبير البيانات الطيفية SpecAugment: أقنعة زمنية وترددية على الطيف	figures/fig-5307-augmentation-specaugment.svg
54	تحويل فوريه على الرسم عبر القاعدة الذاتية للابلاسي والترشيح الطيفي	figures/fig-5401-graph-fourier.svg
54	طبقة المؤثر العصبي الفوريه: تحويل فضرب للأوضاع المحفوظة ثم تحويل عكسي	figures/fig-5402-fno-operator.svg

figures/fig-5403-inr-spectral-bias.svg	التمثيلات الضمنية والتحيز الطيفي ودور SIREN وميزات فوريه	54
figures/fig-5404-neural-compression.svg	خطوة الضغط العصبي: مُرمِّز عصبي ثم تكميم ثم ترميز إنتروبي	54
figures/fig-5405-quantum-signal.svg	معالجة الإشارة الكمية: QFT وتكلفة القراءة مقابل التسريع النظري	54
figures/fig-5406-event-sensing.svg	الاستشعار الحدثي: عينات عند التغير فقط بدل إطارات دورية	54
figures/fig-5407-future-map.svg	خريطة المستقبل: من التحويلات الكلاسيكية إلى المؤثرات العصبية والنماذج التأسيسية للإشارات	54

جُمعت الرموز من جداول الرموز الختامية في الفصول؛ إذا ورد الرمز بمعانٍ متعدّدة أُشير إلى كلٍّ منها. **عدد الرموز الفريدة:** 1010.

الرمز	المعنى	الفصل
$\Leftrightarrow$	تصنيف تامّ	32
$\Leftrightarrow$	تكافؤ	32
$-A^\top y$	انتقال المترافق	22
$(\cdot)_+$	الجزء الموجب $\max(0,\cdot)$	30
(PSD)	شبه-مُحدَّد الإيجابيّة	43
$(1-\mu/L)^k$	تقارب خطّي (قوي التحدّب)	20
$(4n\beta+M)\sqrt{\cdot}$	حدّ التركيز	33
$(em/d)^d$	الصيغة المريحة	31
$[a,b]$	حاوية القيم	17
$[b,d)$	مدى الاستمرار (الميلاد–الموت)	46
$[X,Y]$	قوس لي	48
$[z^n]A$	معامل z^n	49
$*$	التفاف	14
$*$	عملية الالتفاف	40
#pieces	القِطع الخطّية	31
$\|\cdot\|_{L^2}, \|\cdot\|_\infty$	معيارا الطاقة والأسوأ	50
$\|\cdot\|_2$	معيار الطاقة	50
$\|\cdot\|$	أخذ المقدار (لا خطّية)	52
$\|\mathbf{J}\|$	نُرم اليعقوبية	11
$\|\nabla L\|^2$	معدّل الهبوط	12
$\|f-g\|_\infty$	أقصى تغيّر في قيمة الدالّة	46
$\|f\|_{\mathrm{Lip}}$	ثابت ليبنتس لـ f	42
$\|f\|_L \le 1$	قيد ثابت ليبنتس	42
$\|f\|^2$	طاقة الإشارة	49
$\|f\|^2$	طاقة الدالة	50
$\|W_i\|_{\mathrm{op}}$	النظم الطيفي لطبقة	33
$\|W_l\|_{2,1}$	مجموع معايير ℓ_2 للأعمدة	34
$\|W_l\|_\sigma$	المعيار الطيفي للطبقة	31
$\|W_l\|_\sigma$	المعيار الطيفي (أكبر قيمة مفردة)	34
$\|w_t\| = \Theta(\log t)$	نموّ بطيء جدّاً للمعيار	34
$\|w\|^2$	مربّع معيار الحلّ	34
$\|W\|$	معيار المعامل	36
$\|X\|_F$	معيار فروبنيوس للمدخلات	34
$\|x\rangle$	حالة كمّية تمثّل الإشارة	54
α_{ij}	وزن الانتباه من j إلى i	43
α_i	مضاعفات الثنائية	21
α_t	معدّل الخطوة	33
α, β	معاملات Beta سابقة	16
α, β	خطأ النوع الأول والثاني	18
$\alpha : F \Rightarrow G$	تحويل طبيعيّ بين مُقوّمين	47
α	معامل الانتشار	12
α	الإزاحة	22
α	دالّة الاكتساب	25
α	مقياس معاملات الطبقة المخفيّة	40
α	معدّل التعلّم	44
α	المُجمِّع (associator)	47
$1/f^\alpha$	أُسّ الطيف	51
$\bar{A}, \bar{B}$	النسخ المفرّدة	53
$\bar{h}$	متوسط الفرضيات على كلّ العيّنات الممكنة	30
$\bar{K}$	نواة الالتفاف المكافئة	53

$\bar{u}_i = \sum_a \sigma_i(a) u(a, \sigma_{-i})$	العائد المتوسّط	45
$\bar{v}_i$	الـadjoint	36
$\bar{\alpha}_t$	حاصل إشارات المحفوظة	41
$\bar{\gamma}$	الهامش المعيّر	34
$\bar{\sigma}$	متوسط الاستراتيجيّة	45
$\begin{pmatrix} A & B \\ B^\top & C \end{pmatrix}$	مصفوفة كتلية	15
β_1, β_2	عادة 0.9 و 0.999	23
β_e	استقرار الخطأ	33
β_h	استقرار الفرضية	33
β_t	معدّل الضوضاء عند الخطوة t	41
$\beta(t)$	جدول الضجيج	12
$\beta(x_k - x_{k-1})$	قفزة الزخم	23
β	معامل الاحتفاظ (عادة 0.9)	23
β	ثابت الاستقرار الموحّد	33
β	معامل التلاشي	54
$\binom{p}{k}$	عدد اختيارات المؤشّرات	34
$\binom{n}{k}$	المُعامل الثنائي	14
$\boldsymbol{\mu}$	متّجه المُتوسّط	14
$\cosh^{-1}$	جيب التمام الزائدي العكسي	29
$\Delta f / f_s$	عرض الانتقال النسبي	53
δf	خطأ المخرج	11
Δf	دقّة التردد	51
δ_{DP}	احتمال الإخفاق في DP	33
δ_{nm}	دلتا كرونكر	50
Δ_t, Δ_ω	انتشارا الزمن والتردد	52
$\delta_t = \|w_t - w'_t\|$	تباعد مسارين على عيّنتين متجاورتين	33
δ_t	خطأ الفرق الزمنيّ (TD error)	44
$\Delta(A_i)$	المُجْهَز (محدّب مضغوط)	45
$\delta^{(\ell)}$	عقوبة الخطأ	36
$\delta^{(\ell)}$	عقوبة الطبقة ℓ	36
δ	الدلتا (نصف قطر المدخل)	07
δ	نسبة الزيادة المضاعفة	17
δ	احتمال الاستثناء	32
δ	دالة ديراك	51
Δ	خطوة التفريد	53
det	المحدّد	14
$\dot{x}$	المشتقّة الزمنية	12
$\dot{\mathcal{G}}$	مشتقّة النواة بالنسبة لمعاملات الطبقة	40
$\downarrow 2$	تقليل العيّنات	52
هامش ℓ_∞	هامش بمعيار القيمة القصوى	34
ℓ_i	طول شيفرة الرمز i	28
$\ell(\theta)$	$\sum_i \log p(x_i \mid \theta)$	18
$\ell(D \mid m)$	بتّات وصف البيانات مع النموذج	28
$\ell(I)$	حجم الفترة	10
$\ell(m)$	بتّات وصف النموذج	28
$\ell = \log p_\theta$	اللوغاريتم الاحتمالي	15
ϵ_θ	شبكة توقّع الضجيج	41
ϵ_θ	شبكة تقدير الضجيج	53
ϵ	ثابت استقرار ($\sim 10^{-8}$)	23
$\eta_A : A \to T(A)$	يُدخل قيمة في الغلاف	47
$\eta_k \downarrow$	جدولة متضائلة	23
η_k	الخطوة	24
$\eta,\ t$	حجم الخطوة وعددها	34
η, ε	وحدة المرافقة ومُضادّها	47
η	طول الخطوة	20
η	معدّل التعلّم	20، 23
η	معدّل الخطوة	29
$\exp_p$	الخريطة الأُسّيّة عند p	48
$\exp(-2T\gamma^2)$	اضمحلال أُسّي	32
$\forall / \exists$	الكمّيات	07
$\frac{1}{32}$	ثابت الحدّ	32
$\frac{8}{n}$	ثابت الحدّ	31
$\frac{df}{dx}\big\|_a$	مشتقّ لايبنيتس	08

$\frac{p(x,y)}{p(x)p(y)}$	نسبة الاعتماد	26
γ_t	هامش التدريب عند الخطوة t	34
γ, β	معاملات التطبيع	36
γ, η	معلمة القرب / الخطوة	22
$\Gamma(\alpha)$	دالّة غاما	14
$\gamma(h)$	التغوّر الذاتي	19
$\gamma(t)$	منحنى ناعم على M	48
$\gamma(x, y)$	كلّة منقولة من x إلى y	42
$\Gamma^{(\alpha)}$	اتصال α	29
Γ_{ij}^{k}	رموز كرستوفل	48
γ^k	معدّل تقارب تكرار القيمة	44
γ	منحنى على المتشعّب	29
γ	الهامش	31
γ	هامش الضعف (edge)	32
γ	ثابت نعومة التدرّج	33
γ	هامش التصنيف	33
γ	زيادة الخطر التجريبي بسبب الضغط	34
γ	الهامش	35
γ	خصم $[0, 1)$ يضمن تقارب العائد	44
$\hat{A}_{\text{sym}}$	تطبيع تماثليّ للتجاور	43
$\hat{D}$	قطر الفضاء	31
$\hat{f}$	تحويل فوريه	35
$\hat{g}_k = \nabla f_{i_k}$	تقدير غير متحيّز	23
$\hat{h}$	فرضية مُخرَجة	30
$\hat{h}$	ما نملكه فعلاً	30
$\hat{m}, \hat{v}$	مصحّحة الانحياز	23
$\hat{P}_n$	التوزيع التجريبي	17
$\hat{R}_\gamma$	خطر الهامش التجريبي	31
$\hat{R}_\gamma$	خطر التصنيف بهامش γ	34
$\hat{R}_S(h)$	الخطر التجريبي	30
$\hat{X}$	إعادة الإعمار	28
$\hat{y} - y$	التدرّج نحو الدرجات	27
$\hat{y}$	مخرجات softmax	27
$\hat{y}$	احتمالات softmax	36
$\hat{\mathfrak{R}}_n$	تعقيد Rademacher	34
$\hat{\mathfrak{R}}_S$	تعقيد تجريبي	31
$\hat{\mu}_a$	تقدير متوسّط مكافأة الفعل a	44
$\hat{\theta}_{\text{MAP}}$	وضع الخلفيّة (mode)	18
$\inf_{\mathcal{H}} R$	أفضل ما يمكن لـ $\mathcal{H}$	32
$\inf_x$	التقليل الداخلي	21
∞	سعة لانهائية	31
$\int f \, d\mu$	تكامل ليبيسغ	10
$\int x \, dF$	تكامل Stieltjes	13
$\int \|D_N\|$	معيار L^1 للنواة	50
$\int \|f\| d\mu < \infty$	قابلية التكامل	10
κ_t	معلمة الاستكشاف (تنمو ببطء)	25
κ, τ	حرارة المقارنة	53
κ	عدد التكيّف	11
κ	رقم الحالة L/μ	20
κ	سقف النواة $k(x, x)$	31
κ	معامل مضاعفة الدفعة	33
λ_{eff}	التنظيم الضمني للتوقّف المبكر	33
$\lambda_{\min}, \lambda_{\max}$	أصغر وأكبر قيمة ذاتية	20
$\lambda_{\min}, \lambda_{\max}$	أصغر وأكبر قيمة ذاتية لـ Θ	34
$\lambda_{\min}$	أصغر قيمة ذاتية لـ$\Theta(0)$	40
λ_{k+1}	أوّل قيمة «ذيلية» في الطيف	34
λ_2	قابليّة التوصيل (Fiedler)	43
λ_i	قيمة ذاتية	15
λ_i	مضاعف لاغرانج (من 21)	26
λ_j	مضاعف لاغرانج	21
$\lambda_k, \ \phi$	طيف NTK وميزات فوريه العشوائية	51
$\lambda_k(t)$	المنظور الاستمراري k-الأعلى	46
λ_k	القيمة الذاتية k لـNTK	51
λ_k	طيف NTK	54
$\lambda, \ \sigma$	العتبة وانحراف الضجيج	52

$\Lambda^\star$	المجموعة المثلى	50
$\Lambda^\star$	مجموعة المعاملات المثلى للاقتطاع	50
λ	قيمة ذاتية	12
λ	المعدّل	14
λ	المعدّل (أحداث/وحدة زمن)	19
λ	معامل التخميد (damping)	29
λ	قوّة التنظيم	30
λ	قوّة التنظيم = ثابت التحدّب القوي	33
λ	أكبر قيمة ذاتية مطلقة لليعقوبيّة	38
λ	العتبة	52
λ	معامل المفاضلة	54
Λ	نسبة الاحتمال (Likelihood Ratio)	18
Λ	مجموعة معاملات مختارة	50
$\langle f, e_k \rangle$	معامل الإسقاط	49
$\langle \cdot, \cdot \rangle_x$	المقياس الريماني	24
$\langle \cdot, \cdot \rangle$	جداء داخليّ أورثوغونيّ	40
$\lfloor \cdot \rfloor$	القاصي للأسفل	37
$\liminf$	الحدّ الأدنى	10
$\limsup$	النهاية العليا	49
$\ln(1/\varepsilon)$	عامل إضافي تحقّقي	32
$\ln(1/\varepsilon)$	عامل البحث	32
$\ln(4/\delta)$	أثر الثقة	31
$\ln \mathcal{N}$	الإنتروبيا المترية	31
$\log p(\theta)$	عقوبة التنظيم (regularizer)	18
$\log \frac{1}{p(x)}$	مفاجأة الحدث x	26
$\mathbb{E}_\theta$	توقّع التهيئة	40
$\mathbb{E}_S$	التوقّع على تكرار سحب S	30
$\mathbb{E}[\theta \mid X]$	الوسط الخلفي (Bayes estimator) تحت خسارة تربيعية	18
$\mathbb{E}[g(X)]$	توقّع دالة	13
$\mathbb{E}[X]$	التوقّع	13
$\mathbb{E}[X]$	المتوقّع	15، 17
$\mathbb{E}$	التوقّع (من 15)	26
$\mathbb{P}_X$	توزيع X	13
$\mathbb{P}(A_k)$	الاحتمال السابق	16
$\mathbb{P}(A_k \mid B)$	الاحتمال اللاحق	16
$\mathbb{P}(A \mid B)$	احتمال شرطي	13
$\mathbb{P}(B \mid A_k)$	الاحتمال اللاحظي (اللاهوتي)	16
$\mathbb{P}(X \geq a)$	ذيل الاحتمال	15
$\mathbb{P}$	القياس الاحتمالي	13
$\mathbf{1}_{t>0}$	مؤشّر	35
$\mathbf{1}_A$	دالة المؤشّر	10
$\mathbf{h}$	الخطوة	11
$\mathbf{1}$	متّجه الآحاد	43
$\mathcal{C}(\mathcal{H})$	سعة العائلة	54
$\mathcal{C}$	مخطط قاعدة البيانات	47
$\mathcal{D}^n$	توزيع العيّنة	30
$\mathcal{F}_m$	فضاء الشبكة بعرض m	35
$\mathcal{F}_t$	الترشيح (المعلومات المتاحة)	19
$\mathcal{F}$	سيغما-جبرا	10
$\mathcal{F}$	σ-جبرا الأحداث	13
$\mathcal{F}$	كلّ دوالّ الوسم الممكنة	30
$\mathcal{F}$	دالّيّة الطاقة	42
$\mathcal{G}$	نواة NNGP (الأوليّة)	40
$\mathcal{G}$	المؤثّر الهدف	54
$\mathcal{H}, \langle \cdot, \cdot \rangle$	فضاء هيلبرت وجداؤه الداخلي	49
$\mathcal{H}\|_S$	بصمة الفرضيات على S	31
$\mathcal{K}$	جملة مضغوطة	35
$\mathcal{L}_\rho$	اللاغرانجي المعزّز	21
$\mathcal{L}(\theta)$	$\prod_i p(x_i \mid \theta)$	18
$\mathcal{L}(x)$	الحدّ السفليّ للدليل (ELBO)	41
$\mathcal{L}$	اللاغرانجي	21
$\mathcal{L}$	الحدّ الأدنى للتغيّر (ELBO)	29
$\mathcal{M}_r$	متشعّب المصفوفات ذات الرتبة r	24
$\mathcal{M}$	متشعّب التوزيعات	29

$\mathcal{M}$	متشعّب البيانات الكامن	48
$\mathcal{N}(\varepsilon)$	رقم التغطية	31
$\mathcal{T}$	نقل المتّجه	24
$\mathcal{T}$	معامل بيلمان الأمثليّ	44
$\mathcal{T}$	التحويل (فورييه/مويجات/لابلاسي)	54
$\mathcal{T}$	تحويلٌ موحّد يحفظ الطاقة	54
$\mathcal{X}$	فضاء البحث	25
$\mathfrak{R}_n(\mathcal{H})$	متوسط Rademacher	33
$\mathfrak{R}_n$	التعقيد المتوقّع $\mathbb{E}_S[\hat{\mathfrak{R}}_S]$	31
$\mathfrak{W}$	حدّ الانحناء (Weingarten)	24
BC	معامل بَهَتَّشاريا $\sum_k \sqrt{p_k q_k}$	29
Bias^2	مربع انحراف المتوسط عن الحقيقة	30
$\mathrm{cost}(f)$	تكلفة التمرير الأمامي	36
$\mathrm{cut}(A, B)$	وزن الحواف القاطعة	43
$\mathrm{diag}(\cdot)$	مصفوفة قطرية من المتّجه	38
$\mathrm{diam}(\sigma)$	أقصى مسافة بين نقاط σ	46
$\mathrm{epi} f$	الرسم الفوقي (epigraph)	22
$\mathrm{Hess} f$	الهسّية الريمانية	24
$\mathrm{kl}(q\|\|p)$	تباعد برنوليّتين	34
$\mathrm{KL}(Q\|\|P)$	تباعد (KL)	34
KL	تباعد كولباك-لايبلر	41
lo, hi	حدود الفترة	28
$\mathrm{mult}(0)$	تعدّد القيمة الصفريّة = عدد المكوّنات	43
OT_c	كلفة النقل الأمثل	42
$\mathrm{PD}(f)$	مخطط الاستمرار لـ f	46
$\mathrm{prox}_{\gamma g}$	المؤثّر القريب	22
QFT	تحويل فورييه كَمّي	54
ReLU	الوحدة الخطّية المصحّحة	35
Ric, S	الجذريّ والسلّمي	48
$\mathrm{sgn}(k)$	إشارة الفهرس	50
$\mathrm{Si}(\pi)$	تكامل الجيب $\int_0^\pi \frac{\sin t}{t} dt \approx 1.8519$	50
$\mathrm{Si}(\pi)$	تكامل الجيب ≈ 1.8519	50
sinc	نواة إعادة البناء	51
$\mathrm{softmax}(\cdot)V$	تجميع القيم بأوزان الانتباه	39
$\mathrm{St}(p, n)$	متشعّب شتيفل (أعمدة متعامدة)	24
Sublayer	الانتباه أو FFN	39
$\mathrm{sym}(A)$	الجزء المتماثل $\frac{A+A^\top}{2}$	24
TPR, FPR	معدّلا الإيجاب الصحيح والكاذب	33
Variance	حساسية الفرضية للعيّنة	30
$\mathrm{vol}(S)$	مجموع درجات S	43
$\max_i f_i$	الأعظمي يحفظ التحدّب	22
max min	يضمن اللاعب-1 حدّاً أدنى	45
min max	يحاول اللاعب-2 تحديد السقف	45
$\mu_A : T^2(A) \to T(A)$	يُسطّح الغلاف المزدوج	47
μ_B, σ_B^2	متوسط/تباين الدُّفعة	36
μ_F	القياس المرافق	10
$\mu_i \geq 0$	التحديد الثنائي (dual feasibility)	21
$\mu_i g_i = 0$	الركود المكمّل	21
μ_r, μ_g	وسوط الميزات (حقيقيّ/ناتج)	41
μ_t, σ_t	المتوسط والانحراف الخلفيّان	25
$\mu^\star$	أفضل متوسّط مكافأة	44
μ	القياس	10
μ	المُتوسّط	14
μ	المتوسّط	15
μ	$\mathbb{E}[X]$	17
μ	المتوسط الثابت	19
μ	الانحدار (drfit)	19
μ	ثابت التحدّب القوي	20
μ	إحداثيات توقّعية (m-coordinates)	29
μ	ثابت التقلّص القوي أو الزخم	33
$\nabla f(\tilde{x})$	التدرّج الكامل عند المرساة	23
∇f	التدرّج	11
∇f	متّجه التدرّج	20

∇h_j	عمودي على سطح القيد	21
$\nabla_{\mathbf{x}} f$	التدرّج	09
$\nabla_\theta f$	تدرّج الخرج بالنسبة للمعاملات	40
$\nabla_W \mathcal{F}$	تدرّج واسرشتاين	42
$\nabla_X Y$	المشتقّة الاتجاهيّة	48
$\nabla \log p$	السكور	12
$\nabla \log \pi$	تدرّج لوغاريتم السياسة	44
$\nabla^2 f$	الهِسّية	11
$\nabla^2 \ell$	هِسّية اللوغاريتم الاحتمالي	29
∇^2	اللابلاسيان	12
$\nabla^2 f$	مصفوفة الهِسّية	20
∇	مؤثّر الفرق $1 - L$	19
$\odot$	الضرب الإحدائي	23
$\odot$	ضرب عنصري	36
$\odot$	ضرب عنصري	38
ω_0	تردّد التعديل (ناقلة)	51
ω_0	تردّد التفعيل الأولي	54
$\omega_s/2$	تردّد نيكويست	51
ω_s	تردّد العيّنة الزاوي	51
$\Omega(\cdot)$	رتبة سفليّة	32
$\Omega(\mathcal{H}_k)$	عقاب السعة	30
$\Omega(h)$	معقّدية الفرضية	30
$\Omega(W^L)$	حدّ أدنى للأجزاء	35
$\otimes$	الجداء المونيّد (متوازٍ)	47
$\overline{c_k}$	المرافق المركّب	50
$\stackrel{A}{=}$	مساواة بمعنى أبيل	49
$\partial f(x)$	مجموعة التدرّجات الجزئية	22
$\partial h_t / \partial h_k$	مشتقّة الحالة اللاحقة بالسابقة	38
$\partial v_j / \partial v_i$	المشتقّة المحليّة	36
∂Y	تدرّج الخرج	37
$\partial_i \ell$	مكوّنة الدرجة i (score)	29
$\partial \mathbf{u} / \partial \mathbf{v}$	اليعقوبية المعمّمة	09
$\partial^2 = 0$	حدود الحدود معدومة	46
$\perp\!\!\!\perp$	استقلال	14
$\perp$	استقلال	13
ϕ_{hh}	الارتباط الجزئي (PACF)	19
ϕ_i	معاملات الانحدار الذاتي	19
ϕ_s	تحليل طيفي بمقياس s	53
$\phi_X(t)$	الدالّة المميّزة	14
Φ, ϕ	دالّة التوزيع وكثافة الغاوسي القياسي	25
ϕ, ψ	دالة القياس والمويجة	52
Φ, Θ	كثيرات حدود AR و MA	19
ϕ	دالة بسيطة	10
ϕ	نواة التنعيم	52
ϕ	مرشّح تمرير منخفض (تجميع)	52
ϕ	ميزات النواة للانتباه الخطّي	53
Φ	دالّة الإمكان	45
π_{-i}	سياسات الآخرين (البيئة غير الثابتة)	45
$\Pi_{\mathcal{H}}(2n)$	دالّة النموّ عند $2n$	31
$\Pi_{\mathcal{H}}(m)$	أقصى عدد وسوم على m نقطة	31
$\Pi_{\mathcal{H}}(m)$	دالّة النموّ	34
π_A, π_B	إسقاطات الجداء	47
Π_C	مؤثّر الإسقاط	21
$\Pi(p, q)$	مجموعة الانسحابات ذات الهوامش p, q	42
$\pi^\star$	السياسة الأمثل	44
π	التوزيع الثابت	16
π	قطر متشعّب برنولي	29
π	تبديل ترقيم العقد	43
$\prod p(x_i \mid y)$	الجداء اللاحظي	16
$\prod_{i<l} s_i$	جداء الخطوات السابقة	37
$\prod_l \lVert W_l \rVert_\sigma$	جداء المعايير	31
ψ_λ	مويجة بمقياس/اتجاه λ	52
$\psi,\ \phi$	المويجة الأمّ ودالة القياس	52

$\psi,\ \phi$	المويجة ودالة القياس	54
ψ	لوغاريتم القاسم (cumulant)	29
ψ	دالّة محدّبة (Brenier)	42
ψ	المويجة الأُمّ	52
Ψ	تحويل فوريه للمويجة	52
$\Re$	الجزء الحقيقي	52
$\rho(A)$	نصف القطر الطيفي $\max_i \|\lambda_i\|$	49
$\rho(A)$	نصف القطر الطيفي	49
$\rho(h)$	الارتباط الذاتي (ACF)	19
$\rho(W_h)$	نصف القطر الطيفي لـ W_h	38
$\rho(W)$	نصف القطر الطيفي	36
ρ	معامل الارتباط	15
ρ	معلمة العقوبة	21
σ_{-i}	استراتيجيّات الآخرين	45
σ_{sig}	السّيجمويد	35
σ_i	إشارات عشوائية ± 1	31
$\sigma_N,\ A(r)$	متوسط سيزارو، متسلسلة أبيل المثبّطة	49
σ_n^2	تباين الضجيج	25
σ_N	متوسط سيزارو للمجاميع	49
σ_N	مجموع فيير (متوسط سيزارو)	50
σ_t	انحراف خطوة العكس	41
σ_W^2	تباين التهيئة	36
σ'	مشتقّة التنشيط	36
$\sigma(\mathcal{C})$	σ-جبرا المولّدة	10
$\sigma^{(\ell)}$	التنشيط بالطبقة	35
σ^2	قدرة الضجيج الأبيض	51
σ^2	التباين	14، 15
σ^2	$\mathrm{Var}(X)$ من الفصل 15	17
σ^2	متوسط التباينات	17
σ^2	تباين الضجيج	30
σ^2	تباين البعدي الغاوسي	34
σ^2	تباين الضجيج في الوسوم	34
σ	الانتشار (dffiusion)	19
σ	معلَم الضجيج الغاوسي	33
σ	مُبسّط	46
σ	تبديل (permutation) على الفهارس	49
σ	تبديل الفهارس (إعادة ترتيب)	49
σ	عرض الغاوسي	52
σ	انحراف الضجيج	52
Σ	مصفوفة التغاير	14، 15
Σ	مصفوفة التغاير للميزات	41
$\sim$	«تُكتب ك»	50
$\sqrt{d_k}$	معامل التقريب (scaling)	39
$\succ 0$	موجبة التحديد	20
$\succcurlyeq 0$	موجبة نصف التحديد (من 5.15)	20
$\succcurlyeq 0$	الهسّية موجبة نصف التحديد everywhere	20
$\succeq$	ترتيب لوَفنر (أي $A-B$ موجبة نصف محدّدة)	29
$\sum_{\|k\|>N}$	ذيل الطيف	50
$\sum_{i=0}^{d}\binom{m}{i}$	حدّ Sauer الحادّ	31
$\sum_j \mathbb{P}(B \mid A_j)\mathbb{P}(A_j)$	الدليل	16
$\sum \|a_n\|$	متسلسلة القيم المطلقة	49
$\sup_f$	أفضل فرضية تطابق الضجيج	31
$\sup_{x\in D}$	الأسوأ على المجال	49
sup	الأعظمي الأعلى	22
sup	نعلّم T لنعظّم الحدّ	27
sup	السّرب العلوي	35
tanh	الظلّ الزائدي	35
$\tau = 1/(\alpha\mu)$	زمن الخلط	33
τ	زمن التوقّف	19
τ	خطوة الزمن	42
Bias	الانحياز	18
MSE	خطأ المربّع المتوقّع	18
op_i	العملية	36
$\mathrm{Pa}(x_i)$	الآباء	16

$\mathrm{Var}(X)$	التباين	15
Θ_{conv}	نواة التماس الالتفافيّة	40
θ_j	معاملات المتوسط المتحرّك	19
$\Theta(0)$	النواة عند التهيئة	40
$\theta(t)$	مسار المعاملات	12
$\Theta(t)$	مصفوفة النواة في الزمن t	40
$\theta^{(t)}$	تقدير الخطوة t	18
θ	إحداثيات طبيعية (e-coordinates)	29
Θ	فضاء المعلمات	18
Θ	نواة التماس العصبية	34
$\tilde{h}_t$	مرشّح الحالة	38
$\tilde{L}$	لابلاسي معاير	54
$\tilde{O}$	رتبة بلا ثوابت ولا لوغاريتمات	34
$\tilde{x}$	نقطة المرساة	23
$\tilde{\nabla}$	التدرّج الطبيعي	29، 48
$\top$	transpose	36
ε_t	ضوضاء بيضاء	19
ε	الإبسيلون (دقّة الخرج)	07
ε	نصف قطر منطقة الثقة بوحدة KL	29
ε	شبه طوق التقارب الموحّد	30
ε	هامش الخطأ	32
ε	الفجوة فوق الأفضل الممكن	32
ε	ميزانية الخصوصية	33
ε	قوّة الانتظام الإنتروبي	42
ε	مكوّنات الخطأ	54
φ	الكون المزدوج	29
$\widehat{R}_{\mathrm{LOO}}$	مقدّر «اترك واحداً خارجاً»	33
$\widehat{\mathrm{se}}$	الخطأ المعياري المقدّر	18
ξ_i	تراخي المخالفة	21
ξ_k	متّجه الخطوة في المماسّ	24
ξ	نقطة وسيطة	11
ξ	متّجه مماسّي	24
$+C_{out}$	الانحيازات	37
$\lVert\cdot\rVert$	القيمة المطلقة	14
$\lVert \det J_f \rVert$	مُعامل تغيير الحجم	41
$\lVert\mathcal{X}\rVert$	حجم الدعم	26
$\lVert\Sigma\rVert$	محدّد التغاير	14
$\lVert\theta\rVert < 1$	شرط الانعكاسيّة (MA(1))	19
0.08949	نسبة التجاوز الدائم	50
$0 \in \partial f$	شرط الأمثلية	22
$0 < \lVert x - a\rVert$	الاستثنائية	07
$1-\delta$	ثقة الحدّ	30
$1-\delta$	الثقة	32
$1/\lVert w\rVert$	الهامش	21
$1/\gamma$	ثابت لبشيتز لخسارة الهامش	31
$1/\gamma$	عقوبة ضيق الهامش	34
$1/\varepsilon^2$	معدّل غير متحيز	32
$1/\varepsilon^2$	معدّل التركيز	32
$1/\varepsilon$	دقّة التقريب	31
$1/\varepsilon$	معدّل «سريع» تحقّقي	32
10000	أساس التردّد	39
2β	حدّ الفجوة بالتوقّع	33
$2\pi e$	ثابت الغاوسي	26
$2^{\Omega(L/d)}$	عرض ضحل مطلوب	35
2^{kb}	عدد الرسائل بعد التكميم	34
2^m	عدد الوسوم الممكنة على m نقطة	31
$2L/(\lambda n)$	بعد المعلمَين المخرَجين من عيّنتين متجاورتين	33
$2n$	حجم «العيّنة الشبح»	34
$4L^2/(\lambda n)$	بديل 2β	33
$8L^2/\lambda$	بديل $4n\beta$ في (2.33)	33
$a_0/2$	المكوّن المستمر (DC)	50
$a_n,\ S_N,\ R_N$	الحدّ العام، المجموع الجزئي، الباقي	49
a_n, b_n, c_k	معاملات فوريه (حقيقية ومركّبة)	50
a_n, b_n, c_k	معاملات فوريه	54
a_n	الحدّ العام الموجب	49

a_n	معامل التمام	50
A_x	دالة الغموض (ambiguity)	52
$A,\ \Delta$	مصفوفة الحالة وخطوة التفريد	54
$a,\ b$	المقياس والإزاحة	52
$A, \Delta, \bar{K}$	مصفوفة الحالة وخطوة التفريد ونواة SSM	53
A, B, C	مصفوفات الحالة والدخل والخراج	53
a, g	تفعيلات الدخل وتدرّج المخرج للطبقة	29
A'	المتبقّي الخلفيّ (التدرّج)	47
$A(r)$	متسلسلة القوى المثبّطة	49
$A(z),\ X(z),\ H(z)$	دالة مولّدة، تحويل Z، دالة تحويل	49
$A(z)$	الدالة المولّدة (OGF)	49
$A(z)$	مقام دالة التحويل	53
$A \succ 0$	موجبة التحديد	15
$A \succ 0$	كتلة معكوسة	15
$A \succcurlyeq 0$	موجبة نصف التحديد	15
$A \to B$	التمريرة الأماميّة	47
$a^{(\ell-1)}$	نواتج الطبقة السابقة	36
A^k	القوة k للمصفوفة	49
a	مركز التوسّع	11
a	عتبة موجبة	17
a	العتبة	17
a	عمودي المستوي الفائق	22
a	ثابت منحنى التعلّم	33
a	متّجه أوزان الانتباه	43
a	معامل التحجيم	51
a	مقياس (scale)	52
A	مؤثّر خطّي يربط الحدّين	22
A	الميزة المرشّحة للفصل	26
A	خريطة الانتباه $n \times n$	39
$B_2(f)$	نرم بارون	35
B_k	تقدير الهسّية (أو معكوسها)	20
B_k	الحدود (معالم ∂_{k+1})	46
b_n, c_n	حدود معيار ديريكله	49
b_n	متسلسلة مرجعية معلومة	49
b_n	معامل الجيب	50
$B,\ R_x$	معيار الوزن ونصف قطر البيانات	31
$b'(\theta)$	مشتقّة الانحياز	29
$b(s)$	خطّ أساس (غالباً $V(s)$)	44
$B(x, \varepsilon)$	كرة نصف قطرها ε	46
b	حدّة القيمة المطلقة	17
b	حجم الدفعة	33
b	بتّات تخزين المعلمة الواحدة	34
b	إزاحة (translation)	52
B	عرض الحزمة، نسبة الإشارة للضجيج S/N	28
B	عرض النطاق	51
B	مصفوفة ترددات عشوائية	51
B	ترددات الترميز	54
BR_i	أفضل استجابة	45
C_{in}, C_{out}	قنوات الدخل/الخرج	37
C_ψ	ثابت القبول	52
c_1	ثابت النقصان الكافي	20
c_2	ثابت الانحناء (وولف)	20
c_j, w_j, b_j	أوزان/تحيزات/معاملات	35
$c_k(f)$	معاملات f	50
c_k	حدّة الفرق	17
c_k	معاملات التكرارية	49
c_k	المعامل الطيفي	49
c_k	المعامل المركّب	50
C_k	مجموعة سلاسل الأبعاد k (توليدها على حقل)	46
C_t	حالة الخلية (مسار الإضافة)	38
c, f	ثابت؛ دالّة قابلة للعكس	27
$c,\ \phi_s$	شرط التوليد والتحليل الطيفي بمقياس s	53
$C(\mathcal{K})$	الدوالّ المستمرّة	35
c	الثابت	19
c	ثابت التضاؤل في $\alpha_t = c/t$	33
c	ناقل السياق (المعلومات المضغوطة)	38

c	مقدار الإزاحة	52
c	شرط التوليد	53
C	مجموعة محدّبة مغلقة	21
C	مفاضلة الهامش/الخطأ	21
C	السعة	28
C	سقف قصّ التدرّج	33
C	ثابت المجال	35
C	مضاعيف ثابتة	36
C	عتبة التباين	54
$cA,\ cD$	التقريبات والتفاصيل	52
$cA,\ cD$	تقريبات وتفاصيل DWT	54
$d_{\mathcal{M}}$	المسافة الجيوديسيّة داخلياً	48
d_{VC}	أكبر حجم يُحطَم	31
d_{VC}	بُعد VC	31
d_0	بُعد المُدخلات	32
d_{ff}	بُعد الطبقة الداخلية (مخفيّ)	39
$D_{KL}(Q\|\|P)$	تباعد كولباك–لايبler (الفصل 26 لاحقاً)	17
$D_{KL} \geq 0$	متراجحة جيبس	27
D_{KL}	تباعد كولباك–لايبلر (الفصل 27)	26
D_{KL}	الجزء القابل للتقليل	27
D_{KL}	تباعد غير متماثل يحدّد الهندسة	48
$d_{VC} = \Omega(WL)$	بُعد VC لشبكة (ReLU)	34
d_ℓ	عرض الطبقة ℓ	35
D_ψ	تباعد بريغمان	29
d_F	مسافة فيشر–راو	29
d_h	بُعد الحالة المخفية	38
d_i	درجة العقدة i	43
d_k, d_v	بُعد الرأس $(= d_{model}/h)$	39
$D_N,\ K_N$	نواتا ديريكله وفييه	54
D_N, K_N	نواتا ديريكله وفييه	50
D_N	نواة ديريكله	50
d_x	بُعد الدخل	38
d_y	بُعد الخرج	38
$d-1$	يظهر بدل d	32
$d,\ K,\ R$	التوسيع وحجم النواة والحقل الاستقبالي	53
D, G	المميّز والمولّد	53
$d(\cdot,\cdot)$	دالّة تشويه	28
$D(p\|\|q)$	تباعد كلولباك–لايبلر	29
$D(x)$	احتمال "حقيقيّ" من المُميّز	41
$d \ln \frac{2en}{d}$	أثر السعة	31
$d^\star$	القيمة المثلى الثنائية	21
d	البُعد	14
d	رتبة التفاضل	19
d	اتجاه الهبوط	20
d	بُعد VC	32، 33
d	بُعد التضمين	38
d	معامل التوسيع	53
D	حجم الأبجديّة (2 للبتّ)	28
D	حدّ التشويه	28
D	مجال التقارب	49
d في الأُسّ	البعد الفعّال	31
dF_X	عنصر القياس	15
dF	الإجراء (measure element)	10
dW_t	زيادة وينر اللامتنهية	19
E_{alias}	طاقة ما سيُشوّه	51
E_θ, D_ϕ	المُرمِّز والمُفكِّك	54
e_i	متّجه الكلمة i	38
$e_k,\ c_k,\ P_N$	متجه عمودي، معامل طيفي، إسقاط	49
e_k	متجه عمودي معياري	49
E_N	فضاء المكوّنات الأولى	49
E, O	تحويلا الفهارس الزوجية والفردية	51
$e(t) = f(t) - y$	خطأ التدريب	40
$e^{-\Theta t}$	أُسّ المصفوفة	34

$e^{-\Theta t}$	كسر المصفوفة الأسّ	40
e^{ikx}	الأسّ المركّب	50
e^T	أسّيها	27
e	حدث (موضع وزمن وقطبية)	54
E	مصفوفة التضمين	38
-geodesic$e$	جيوديسيّ الاتّصال (-1) (خطّي في المتوسّط)	48
$f_{\text{مرئي}}$	التردد الذي سنراه	51
F_{ii}	قطر فيشر	29
F_{jk}	مرشّحات mel المثلثية	52
$f_{X,Y}$	كثافة مشتركة	14
f_θ	شبكة التدفّق	12
f_θ	الشبكة بوصفها دالة	54
f_c	التردّد المركزي	52
f_i	دالّة الميزة/القيد	26
f_k	عدد المُبسّطات k-الأبعاد	46
$f_n \uparrow f$	تقارب رتيب	10
f_r	كلفة المصدر r	45
$f_s,\ B$	معدّل العيّنة وعرض النطاق	54
$f_s,\ T_s,\ B$	معدّل العيّنة، زمنها، عرض النطاق	51
f_s	معدّل العيّنات	51
f_t, i_t, o_t	بوّابات النسيان/الدخل/الخرج	38
f_t	مُخرجات الشبكة على العيّنة عند الزمن t	34
$f_X(x)$	كثافة الاحتمال	14
f_X	كثافة الاحتمال	13
f_X	كثافة هامشية	14
F_X	دالة التوزيع التراكمي	13
f, g	محدّبتان مغلقتان	22
$f'_{\pm}(a)$	الميلان الأحادية	08
$f'(a)$	مشتقّ لاغرانج	08
$F(\theta)$	مصفوفة فيشر (مقياس التوزيع)	48
$f(1) = 0$	شرط التطابق	27
$f(x_i; t)$	خرج نقطة i في زمن t	40
$f(x, t)$	انجراف (drfit)	41
$f(x)$	الدالّة الحقيقية (القيمة المتوقّعة)	30
$f(x^{\pm})$	النهايتان من اليمين واليسار	50
$F \dashv G$	مرافقة (adjunction)	47
$f^{-1}(B)$	الصورة العكسية	10
$f^{(k)}$	المشتقّة k	11
$f^{\star\star}$	المترافق المزدوج	22
$f_t^\star$	أفضل قيمة حتى t	25
$f^\star$	الدالّة المترافقة	22
f^+, f^-	الأجزاء الموجبة/السالبة	10
f	الحقل الاتجاهي	12
f	دالة متماسكة محلياً	17
f	سلسة بـ L	22
f	الكثافة	26
f	مُولّد التباعد	27
f	تحويل قابل للعكس	41
f	الناقد (critic)	42
f	دالّة المُرشّح (filter)	46
f	دالة متناقصة تمرّ بـ a_n	49
F	دالة كثافة التوزيع (CDF)	10
g_{auto}	تدرّج آليّ	36
g_{num}	تدرّج عددي	36
g_{ij}	مكوّنات المتر المعلوماتي	29
g_{ij}	مصفوفة المقياس (متماثلة موجبة)	48
g_θ	الجزء المتعلّم	54
$g_i \leq 0$	التحديد الأولي (primal feasibility)	21
G_k	تراكم المربّعات (AdaGrad)	23
g_t	مرشّح الخلية	38
G_t	العائد من الخطوة t	44
$g(\cdot)$	استجابة المرشّح الطيفي	54
$g(\lambda, \mu)$	الدالّة الثنائية	21
$g(t)$	معامل انتشار الضوضاء	41

$G(z)$	عيّنة مولّدة	41
$g^t(a)$	فوز الفعل a في الجولة t	45
g	دالّة التحويل	14
g	دالّة محوّلة	15
g	تدرّج جزئي	22
g	محدّبة غير سلسة (كـ L1)	22
g	عدد المجموعات	37
g المرافق	دالة الإخضاع	10
g محدّبة	دالّة محدّبة	15
get	قراءة جزء من الحالة	47
H_{dec}	حالة فكّ التشفير	39
H_{enc}	مخرجات المشفّر	39
h_{LP}	مرشّح تمرير منخفض	51
H_0, H_1	الفرضية الصفرية والبديلة	18
H_0 : جذر وحدة	اختبار ADF	19
H_f	هسّية الهدف	11
$h_k,\ b_k,\ a_k$	معاملات FIR والتلقيمين الأمامي والراجع	53
h_k	الاستجابة النبضية	53
h_S	الحلّ النظري لـ ERM	30
h'_t	حالة فكّ التشفير	38
$h,\ g$	مرشّحا التمرير المنخفض والعالي	52
h, g	مرشّحا التمرير المنخفض والعالي	52
$H(p)$	إنتروبيا الحقيقة (لا نتحكّم بها)	27
$H(X, Y)$	الإنتروبيا المشتركة	26
$h(X)$	الإنتروبيا التفاضلية	26
$H(X)$	الإنتروبيا (بتّات إن كان الأساس 2)	26
$H(Y \mid A)$	الشكّ المتبقّي بعد الفصل	26
$H(Y \mid X)$	إنتروبيا Y بعد معرفة X	26
$H(z),\ A(z),\ B(z)$	دالة التحويل ومقامها وبسطها	53
$H(z)$	دالة التحويل (transfer)	49
$H(z)$	دالة تحويل المرشّح	54
$h * x,\ H \cdot X$	الالتفاف وضرب الطيف	51
$h * x$	الالتفاف (convolution)	49
$h * x$	الالتفاف في الزمن	51
$H \cdot X$	الضرب في التردد	51
$H^{-1}\nabla f$	خطوة نيوتن	20
$H^{(l)}$	مصفوفة ميزات الطبقة l (كلّ صفّ عقدة)	43
h	الزيادة	08
h	حجم الخطوة	12
h	خطوة الفروق	36
h	عدد الرؤوس	39
H	القفزة (hop)	52
i_k	الفهرس المرسوم عشوائيّاً	23
$I_n = nI_1$	معلومة العيّنة	29
I_p	مصفوفة الوحدة	24
$I(\theta)^{-1}$	حدّ التباين	15
$I(\theta)$	معلومات فيشر	15، 18
$I(X; Y)$	المعلومات المتبادلة	26
$I(X; Z)$	معلومات متبادلة (من 26)	27
I^{-1}	معكوس متر فيشر (أو شبه معكوس)	29
i	الوحدة التخيّلية	14
i	مؤشّر البُعد	39
I	كائن الوحدة	47
I	مثال (يُعيّن مجموعة لكلّ كيان)	47
IG	كسب المعلومات	26
$J_{\mathbf{f}}$	اليعقوبية	09
J_f	يعقوبية الحقل	12
J_f	مصفوفة جاكوبيّ f	41
J_r	يعقوبية المتبقّي	11
$J(g, f)$	تشويه المسافة (stress)	48
J	الجاكوبي	14
J	سعة القفزة	50
K_{ij}	نواة غيبس $e^{-c_{ij}/\varepsilon}$	42
k_l	حجم نواة الطبقة l	37
K_N	نواة فيير	50

k_p	حجم نافذة التجميع	37
$k(\cdot,\cdot)$	نواة على المخطّطات	46
$K>0, K=0, K<0$	كروي، مسطّح، سرجيّ	48
k	دالّة النواة (kernel)	25
k	عدد الفترات/الحدود	32
k	عدد الأضعاف	33
k	عدد معلمات الوصف المضغوط	34
k	حجم النواة	37
k	بُعد/عدد الجيران المُختزَل	39
k	عدد الانزياحات الطيفية	51
K	مصفوفة النواة على النقاط المرصودة	25
K	عدد المرشّحين المُختبرين	30
K	عدد الفئات	33
K	الانحناء القسميّ	48
K	حدّ القطع في نيومان	49
K	حجم النواة	53
K	رتبة كثير الحدود	54
K	عدد الأوضاع المحفوظة	54
K	ميزانية المكوّنات	54
L_{simple}	خسارة إزالة الضجيج	41
$L_2(S)$	المعيار التجريبي $\sqrt{\frac{1}{n}\sum f(z_i)^2}$	31
$L,\ r,\ p$	نهايات النسبة/الجذر، حدّ رابه، أُسّ المقارنة	49
$L,\ U$	لابلاسي الرسم وقاعدته	54
$L(\gamma)$	طول المنحنى	29
L/n	معدّل البتّات لكلّ رمز	28
$L^\star$	طول التحول إلى FFT	53
$L^{3/2}$	عقوبة العمق	34
L^1	تكامل القيمة المطلقة	35
$L^2(\mu)$	خطأ تربيعي متوسّط	35
L	الخسارة	12
L	مؤثّر التأخّر	19
L	ثابت ليبشتز للتدرّج (السلاسة)	20
L	متوسط الطول	28
L	عدد الطبقات	31
L	ثابت لبشيتز: $\|\ell(w,z)-\ell(w',z)\| \le L\|w-w'\|$	33
L	العمق	35
L	طبقة التفاف	37
L	نهاية النسبة أو الجذر	49
L	طول الإشارة الكلّي	52
L	طول المرشّح	52
L	طول النواة	53
L	عدد الطبقات	53
m_i	هامش النقطة i	34
m_k	اللحظة الأولى (الزخم)	23
M_k	مسيرة عند الخطوة k	17
M_n	سقف عددي مستقل عن x	49
M_t^-/M_t^+	مارتنغيال فرعي/أدنى	19
M_t	المارتنغيال	19
$M_X(t)$	MGF	14
$M_X(t)$	الدالة المولّدة للحظات (الفصل 14)	17
m,n	إزاحة داخل النواة	37
$m(E)$	قياس ليبيسغ	10
$m \le d$	$\Pi = 2^m$	31
$m^*(E)$	القياس الخارجي	10
m	عدد الأحداث في الاتحاد	17
m	دالّة المتوسط السابقة	25
m	عدد الأوراق	32
m	نافذة التوسيط	33
m	عرض الطبقة المخفيّة	34
m	عرض الطبقة المخفية	35
m	عرض الشبكة (عدد الوحدات)	40
m	رتبة النعومة	50
m	فهرس الإطار الزمني	52
m	عدد بِتّات الدقة في تقدير الطور	54
M	أقصى مشتقّة	11

M	سقف الخسارة	33
M	دالّة الرسالة	43
M	مصفوفة منافع اللاعب-1	45
M	المتشعّب	48
-geodesic$m$	جيوديسيّ الاتّصال $(+1)$ (خطّي في الوسيط)	48
N_{group}	معاملات grouped	37
N_{param}	عدد المعاملات	35
N_{sep}	معاملات separable	37
N_a	عدد مرّات سحب a	44
n_k	عدد عيّنات العميل	25
n_r	عدد اللاعبين على المصدر r	45
$N - n$	النقاط غير المشاهدة	30
$n(1 - 1/k)$	حجم تدريب الطيّة	33
$N(t)$	عدد الأحداث حتى t	19
$n\beta$	**الكمية الحاكمة**	33
$n \log_2 \|\|\mathcal{Y}\|\|$	بتّات لازمة لحفظ الوسوم	34
$n \propto d/\varepsilon^2$	قانون تعقيد العيّنة	31
$n + 1$	العرض الكافي	35
n	عدد التجارب	14
n	حجم العيّنة	17
n	الإجمالي	25
n	بُعد المُدخل	35، 36
n	طول المتسلسلة	39
n	رقم التوافقيّة (harmonic)	50
n	طول السياق	53
N	طول الإطار	51
N	طول النافذة المنفصلة	52
N	طول الإشارة	53
nH	طول تقريبي للسلسلة	28
O_p	بُعد المخرج بعد التجميع	37
$O(\|\|d\|\|^3)$	حدّ من الرتبة الثالثة	29
$O(\cdot)$	ترتيب كبير	11
$O(\log^2 N)$	تكلفة البوابات	54
$O(1/\sqrt{K})$	معدّل التقارب للمحدّب	23
$O(1/k)$	تقارب دون خطّي (محدّب)	20
$O(1/K)$	معدّل نُرم التدرّج	24
$O(1/k^2)$	معدّل مسرّع	22
$O(1/N)$	عرض منطقة التجاوز	50
$O(k^{-(m+1)})$	معدّل الذيل	50
$O(n^2 d)$	تعقيد الانتباه الكامل	39
O	بُعد المخرج	37
p_{ij}	نموذج الإنتروبيا	54
P_{T_x}	إسقاط متعامد	24
P_n	متعدّدة تايلور	11
P_N	الإسقاط العمودي على E_N	49
P_N	الإسقاط على أول N	50
$p_X(k)$	كتلة الاحتمال	14
p_X	كتلة الاحتمال	13
$p(\theta)$	السابق	16
$p(\theta)$	السابق (prior)	18
$p(\theta \mid x)$	اللاحق	16
$p(\theta \mid X)$	الخلفيّة	18
$p(x)$	الدليل	16
$p(x \mid \theta)$	اللاحظي	16
$p(y)$	السابق الصنفي	16
$p(y \mid x)$	التوزيع الشرطي (من 16)	26
$p(y \mid x)$	مصفوفة القناة	28
$p\,b$	ميزانية البتّات	34
$p \log p$	باتفاق $0 \log 0 = 0$	26
$P^{\perp}$	الإسقاط العمودي	24
P^{π}, r^{π}	مصفوفة الانتقال والمكافأة تحت π	44
$p^\star - d^\star$	فجوة الثنائية	21
$p^\star$	القيمة المثلى الأولى	21
p	الرتبة	11
p	احتمال النجاح	14

p	رتبة النموذج	19
p	التوزيع الحقيقي (هدف/thحقيق)	27
p	عدد المتغيّرات المنطقية	32
p	عدد المعلمات	33
p	عدد معلمات الشبكة الأصلي	34
p	أُسّ المقارنة في $\sum 1/n^p$	49
P	مصفوفة الانتقال	16
P	توزيع قبلي قبل رؤية البيانات	34
P	طبقة تجميع	37
P	كائن المعاملات (الأوزان)	47
pos	رقم الموضع (...,0,1,2)	39
q_t, c_t	استعلام وتمثيل كامن مستهدف	53
Q, K, V	الاستعلام والمفتاح والقيمة	53
Q, K, V	استعلام/مفتاح/قيمة الانتباه	53
$q(z \mid x)$	المُقرّب البعديّ	41
Q^π	قيمة البدء بفعل من حالة	44
$q = b/n$	معدل أخذ العيّنات	33
q	توزيع النموذج	27
Q	دالة التوقّع	18
Q	توزيع بعدي بعد التعلّم	34
Q	التكميم	54
$QK^\top$	درجات التشابه (نقاط)	39
$r_k(\Sigma)$	رتبة فعّالة بالقيمة المفردة الكبرى	34
$R_k(\Sigma)$	رتبة فعّالة بمجموع المربّعات	34
R_k	مصفوفة الأوزان للوضع k	54
R_n	البقايا	11
R_n	خطأ القطع	11
R_N	الباقي بعد N	49
r_t	بوّابة إعادة الضبط	38
R_T	الندم التراكمي	25
$R_x,\ S_x$	الارتباط الذاتي وطيف القدرة	51
$R_x(\tau)$	الارتباط الذاتي	51
R_x	الانكماش (بديل الخريطة الأسّية)	24
R_x	إرجاع من المماسيّ إلى المُشعّب	48
R, D	المعدّل والتشويه	54
r, n	نجاحات/تجارب	16
$R(D)$	دالّة معدّل–تشويه	28
$R(h)$	خطر التعميم	30
$R(Q), \hat{R}(Q)$	خطري التوزيع البعدي	34
$R(T)$	الندامة التراكميّة	44
$R^\star$	خطر بايز	30
r	خطأ نسبيّ	36
r	حدّ راابه	49
r	عامل التثبيط $r \to 1^-$	49
R	معدّل المعلومات المرسلة	28
R	أقصى نصف قطر	35
R	مُلْويّ الانحناء	48
R	نصف قطر التقارب	49
R	نصف قطر التقارب؛ وطاقة الإشارة في سياق بارسيفال	49
R	مصفوفة المزج الطيفي	51
R	الحقل الاستقبالي	53
R	أوزان المزج الطيفي	53
RF_l	الحقل الاستقبالي عند الطبقة l	37
S_{-j}	كلّ البيانات عدا الضعف j	30
S_ε	تباعد Sinkhorn المصحّح	42
s_i	خطوة الطبقة i	37
S_i	فاصل الوصول (inter-arrival)	19
S_j	الضعف المحتجز	30
S_j	معاملات التشتّت بالعمق j	52
s_k, y_k	فرق الموضع وفرق التدرّج	20
S_k	المجموع الجزئيّ k	49
$S_N,\ \sigma_N$	المجموع الجزئيّ ومجموع فيير	54

S_N, σ_N	المجموع الجزئيّ ومجموع فيير	50
S_N	المجموع الجزئيّ N	50
S_N	المجموع الجزئي	50
s_p	خطوة التجميع	37
$S_x(\omega)$	طيف القدرة (PSD)	51
$s(x,t)$	السكور $\nabla_x \log p_t$	41
$S(x)$	دالة النهاية	49
$S^{i,z}$	عيّنة مجاورة	33
S^{n-1}	كرة الوحدة	24
s	انحناء الهدف في مؤلّفة ما	33
S	المكمّل الشورّي	15
S	الهدف في إعادة الترتيب	49
set	تحديث الجزء مع بقاء الباقي	47
$T_\# p = q$	T تدفع p إلى q	42
$T_\theta \mathcal{M}$	الفضاء المماس	29
t_0, ω_0	مركزا الزمن والتردّد	52
t_0	إزاحة زمنية	51
T_g	عملية ترجمة بإزاحة g	40
T_i	زمن الحدث i	19
t_k	معامل نيستروف	22
t_k	زمن تعلّم المكوّن	51
T_k	متعدّدات تشيبيشف	54
$T_p M$	الفضاء المماسيّ	48
T_s	زمن العيّنة	51
T_w	فترة التسخين (warmup)	23
$T_x \mathcal{M}$	فضاء المماسّ	24
T_x	إزاحة (ترجمة) بـx	37
t, f	طول القناع الزمني والترددي	53
$T(x)$	الإحصاء الكافي	29
$T(X)$	إحصاء كافٍ	18
$t = p/q$	نسبة الكثافة	27
t	المتغيّر المزدوج	14
t	بُعد الانحراف	15
t	عتبة الانحراف	17
t	معامل الإمالة الأسّي (tilt)	17
t	عتبة المجموع	17
t	وزن المزج في $[0, 1]$	22
t	الخطوة الزمنية	38
T	إجمالي التكرارات	23
T	ميزانية التقييمات	25
T	دالّة مرشّحة (سنرى شبكة)	27
T	درجة الحرارة (temperature)	27
T	عدد جولات التعزيز	32
T	عدد الخطوات الكلّي	33
T	عدد الأخطاء	35
T	مُقوّب داخليّ (يغلّف القيم)	47
U_c	كمون clique	16
u_k	متّجه ذاتيّ معياريّ	43
u'_n	مشتقة الحدّ	49
$u_n(x)$	حدّ دالّي (دالة لا عدد)	49
U_n	مجاميع جزئية لـu	49
U, ϕ	حيّز مخطط وخرائطه	48
u, v	مُعاملات التحجيم الصفّي/العموديّ	42
U, V	المتّجهات المفردة اليسرى/اليمنى	24
$u(a, \sigma_{-i})$	عائد الفعل a مقابل الخصم	45
u	الحقل	12
U	وزن ربط السياق	38
U	دالّة تحديث العقدة	43
U	قاعدة القيم الذاتية للابلاسي	54
V_{th}	عتبة الإطلاق	54
v_i	عقدة	36
V_j, W_j	فضاءات القياس والتفاصيل	52
v_k	سرعة/زخم متراكم	23
v_k	متوسّط متحرّك (RMSProp)	23

v_k	اللحظة الثانية (المقياس)	23
v_t	الحقل في الطبقة t	54
V_t	جهد الغشاء في العصبون النبضي	54
$V(D,G)$	قيمة اللعبة	41
V^π	قيمة البدء من حالة	44
$V^\star, Q^\star$	القيم الأمثلى	44
v	قيمة اللعبة	45
V	مجموعة التحقّق	30
V	حجم المفردات	38
w_{SVM}	حلّ أقصى هامش (آلة الدعم)	34
$W_{x_1x_2}$	الحدّ المتقاطع	52
W_∞	مسافة Wasserstein-∞ (أقصى انطباق)	46
W_ε	كلفة النقل المنتظَمة	42
W_1	مسافة واسرشتاين-1	42
W_2	واسرشتاين-2	42
W_d	استجابة النواة الموسّعة	53
W_h	وزن الحالة	38
w_k	أوزان النواة المتعلَّمة	53
W_L	أوزان الطبقة الأخيرة	40
W_N	جذر الوحدة الأولي	51
W_N	جذر الوحدة الأولي $e^{-2\pi i/N}$	51
W_t	عملية وينر (الحركة البراونية)	19
$W_x,\ A_x$	توزيع فيغنر–فيل ودالة الغموض	52
W_x	توزيع فيغنر–فيل	52
$w,\ H$	نافذة التحليل وقفزتها	52
w, b	المستوي الفائق	21
w, r, s	نافذة محلية، عشوائي، عام	53
$W(\omega)$	استجابة النواة الترددية	53
$w(b,d) = d - b$	وزن الاستمرار	46
$w[n]$	النافذة (Hann/Hamming/Blackman)	51
$W^{(\ell)}$	مصفوفة الأوزان	35، 36
$w^{(k)}$	نموذج العقدة/العميل k	25
$W^{(l)}$	أوزان الطبقة القابلة للتعلّم	43
$w^\star$	«الفاصل الأمثل»	35
W^O	إسقاط الدمج	39
w	وزن المتعلّم	35
W	عدد الأوزان	31
W	العرض	35
W	مصفوفة الأوزان	37
X_{col}	المُدخل المفرد (patches) كأعمدة	37
x_0	مقدار الإزاحة	50
$x_i,\ y_i \in \{-1,+1\}$	نقطة وعلامتها	35
x_i	الميزة i	16
X_i	العيّنة الجزئيّة قبل التجميع	46
x_n	التقريب عند t_n	12
X_s	طيف الإشارة المعيّنة	51
x_t	الحالة عند الخطوة t	41
x_t	العيّنة عند الزمن t	53
$X(\omega),\ X[k]$	الطيف المتّصل والمنفصل	51، 54
$X(\omega)$	الطيف (مطال وطور)	51
$X(z)$	تحويل Z للإشارة x_n	49
$X[m,k],\ S[m,k]$	STFT والمخطوط الطيفي	52
$X \succ 0$	موجبة التحديد (من 5.15)	24
$X^{-1}(B)$	الصورة العكسية	13
x^+, x^-	إيجابية وسلبية	53
x^*	نقطة ثابتة	12
$x^\star$	النقطة المثلى المحلّية	20
$x^\star$	الخيار الأفضل	25
$x^\top Ax$	صيغة تربيعية	15
$x^\top \xi = 0$	شرط المماسّية	24
X	متغيّر عشوائي	13
X	متغيّر عشوائي غير سالب	17
$y_{<t}$	الرموز المولَّدة سابقاً	39
y_i	الهدف	40
y_k	نقطة الاستباق (extrapolation)	22

y_k	نقطة الاستباق	23
y_t^*	الرمز الحقيقي المستهدف	38
$Y(i,j,c)$	قيمة المخرج	37
$y\,h(x)$	هامش النقطة	31
$y^\top \Theta^{-1} y$	تعقيد النواة	34
y	الفئة	16
y	التسمية (واحد ساخن)	27
y	الهدف (one-hot)	36
y	مؤشّر الانتقاء (مُرخّى)	43
$z_{\alpha/2}$	كمّية التوزيع الطبيعي القياسي	18
z_0	مركز المتسلسلة	49
Z_k	الدورات (سلاسل لها حدّ صفر)	46
z_t	بوّابة التحديث	38
z^{-1}	عنصر تأخير بوحدة زمن	49
$z^{(\ell)}, a^{(\ell)}$	ما قبل/بعد التنشيط	35
z	المسافة المعيارية عن الأفضل	25
z	متغيّرات كامنة	29
Z	دالّة التقسيم	16
Z	المتغيّر الكامن	18
Ω	فضاء العيّنات	10، 13
اتساق	تقارب الخطر إلى أفضل ما في $\mathcal{H}$	30
ازدواج	تكافؤ الصيغتين	30
استعلامات إحصائية	نموذج SQ	32
استقلال	$H(X,Y) = H(X) + H(Y)$	26
استكشاف/استغلال	مفاضلة أساسية	25
استيعاب	$\hat{R}_S(\hat{h}) = 0$	34
استيعاب حميد	مع خطر اختبار صغير $\hat{R} = 0$	34
استيعاب خبيث	مع خطر اختبار كبير $\hat{R} = 0$	34
إسقاط e	يقلّل $D(p\|q)$	29
إسقاط m	يقلّل $D(q\|p)$	29
أسوأ الحالات	الحدّ السفلي يطابق	32
أسّية	عائلة التوزيعات الناتجة	26
إعادة التحجيم	عند نقص الدقة العددية	28
أفضل استجابة	$BR_i(\sigma_{-i}) = \arg\max_{\sigma_i} u_i$	45
السياسة المشتركة	تعظيم مجموع العوائد للفريق	45
الفصّ الرئيسي	عرض قمّة النافذة الطيفية	51
الفصوص الجانبية	ذيل النافذة	51
القطر	$D = 0$ حيث $\theta = \theta'$	29
المصحّح	يلغي التباين تدريجياً	23
الممثّل	يحدّث θ (السياسة)	44
الناقد	يحدّث w (القيمة)	44
النقل المتوازي	إزاحة V بلا تدوير محلّي	48
امتداد كان	نقل بيانات حقيقيّ (تجميع/إسقاط)	47
انحياز استقرائي	افتراض مسبق عن $\mathcal{D}$	30
انحياز ضمني	تفضيلٌ للحلول بلا عقوبة صريحة	34
بصرية	أماميّ + خلفيّ (تمريرتان)	47
تأهّل	شرط نقطة داخلية	22
تحديث λ	صعود ثنائي بخطوة ρ	21
تحسين	قصور المُحسّن	30
تحطيم	$\|\mathcal{H}_{\|S}\| = 2^m$	31
تحقّقي	الصفر attainable	32
تدريب كسول	النواة ثابتة، المعلمات لا تتحرّك كثيراً	34
تذكرة اليانصيب	وصف: مؤشّرات + تهيئة	34
تراكم أُسّي	$v \propto \sum \beta^j \nabla f$	23
تسخين	رفع تدريجي من الصفر	23
تشينتسوف	وحدانية المتر الثابت	29
تصحيح	يقيس التدرّج حيث سنكون	23
تصحيح الاتّحاد	$\delta \mapsto \delta/K$	30
تطبيع	الانكماش على الكرة	24
تعلّم التكافؤ	noise with parity	32
تعلّم التمثيل	النواة تتغيّر مع التدريب	34

تقارب موحّد	$\sup_{h\in\mathcal{H}} \|\cdot\| \to 0$	30
تقارب موحّد	$\sup_{\mathcal{H}} \|\cdot\| \to 0$	30
تقدير	قصور n	30
تقريب	قصور $\mathcal{H}$ عن الحقيقة	30
تقريب	العلاقات «$\approx$»	32
تقليل بالتكييف	المعلومات تخفض الشكّ	26
تقييم مكلف	كلّ تجربة ثمينة	25
تلاشٍ/انفجار	اختفاء/تضخّم $\delta^{(1)}$	36
تماثل	$I(X;Y) = I(Y;X)$	26
تنوّع محدود	عددٌ منتهٍ من الارتدادات	50
توزيع مخصّص	أسهل أحياناً	32
ثبات إعادة المعْلمة	مسار NG لا يتغيّر بتبديل الإحداثيات	29
ثنائية مقعّرة	g مقعّرة دائماً	21
جنسن	الأداة الأساسية (من 4.15)	26
جولات	دورات التواصل	25
جيب التمام	تناقص سلس حتى النهاية	23
حدّ سفلي	ما لا يمكن تجاوزه	32
خارج-السياسة	السياسة السّلوكيّة تختلف عن الهدف	44
خريطة أسّية	الانكماش الدقيق (geodesic)	24
خطأ التقدير	قصور العيّنة S	30
خطأ التقدير	ما تقلّله العيّنة	32
خطأ التقريب	قصور $\mathcal{H}$ عن تمثيل الحقيقة	30
خطأ التقريب	$\inf_{\mathcal{H}} R - R^\star$	32
خطوة ثابتة	بفضل تضاؤل التباين	23
داعم	يماسّ ولا يقطع الداخل	22
ذراع	خيار متاح	25
رسم شريطي	أسلاك = كائنات، صناديق = سهام	47
زخم	الفرق $(x_k - x_{k-1})$ بوزن	22
زمن حدودي	poly في المعاملات	32
سحب عكسيّ	(إعادة تسمية/دمج) $I \circ F$	47
سلاتر	نقطة ممكنة داخلية	21
سلاسة مقارنة	$\|f(R_x(\xi)) - f(x) - \langle \mathrm{grad} f, \xi\rangle\| \le \frac{L}{2}\|\xi\|^2$	24
سلسة	$\partial f = \{\nabla f\}$	22
سهم	تحويل بين كائنين	47
شجرة	بنية بثنائيّة	28
صحيح/غير صحيح	داخل/خارج $\mathcal{H}$	32
صندوق أسود	لا تدرّج ولا بنية معلومة	25
طور خطّي	تأخيرٌ ثابت لكلّ الترددات	53
طول الوصف	الميزانية المعلوماتية	34
عالمية	كلّ نقطة حرجة عالمية	20
غابور	نواة غاوسية معدّلة	52
غير فارغ	الهامش < 1	34
غير متحيز	$\mathbb{E}[\hat\theta] = \theta$	29
غير متحيّز	مقارنة بأفضل ما في $\mathcal{H}$	32
فارغ (vacuous)	الحدّ $\ge$ أقصى خطر ممكن	34
فترة جزئية	جزء متداخل من $[0,1)$	28
فجوة التمثيل	أثر اختيار القاعدة	54
فريد فكّ الترميز	لا لبس في فكّ الشيفرة	28
فصل صارم	$a^\top z > \alpha \ge \sup_C a^\top x$	22
فوري	prefix-free	28
فوري (prefix-free)	لا شيفرة بادئة لأخرى	28
فورية (prefix-free)	لا شيفرة بادئة	28
فيشر	g_{ij}	48
قانون العدسة	اتساق القراءة/التحديث	47
قناع حشو	يستبعد رموز PAD	39
قناع سببيّ	يمنع رؤية المستقبل	39
كائن	عقدة (مثل فضاء متّجهيّ أو مجموعة)	47
كثير حدود	$\Pi(m) = O(m^d)$	31
كفاءة	نسبة الحدّ إلى التباين الفعلي	29
لا يعتمد على التوزيع	خصائص تركيبية بحتة	31
لا يعتمد على الخوارزمية	الحدّ لكلّ $h \in \mathcal{H}$	31
لا يوجد مجّان	كلّ تحسين له ثمن	32

لامتغيّر	ds^2	29
لكلّ $\mathcal{D}$	distribution-free	32
ماركوف	تكييف (conditional independence)	27
ماسّار	حدّ للفضاءات المنتهية	31
مترافق	conjugate	16
متصلة قطعياً	عددٌ منته من القفزات	50
متعلّم ضعيف	أفضل قليلاً من الصدفة	32
متعلّم قوي	خطأ ε كيفما صغر	32
مجموعة نموذجيّة	تسلسلات «شائعة» (AEP)	28
محدّبة	القطعة المستقيمة فوق الرسم	20
محدّبة	يضمن عدم السلبية	27
مستوٍ e/m	استواء مزدوج	29
مسقوط	خطوة تدرّج ثمّ إسقاط	21
معادلة القاطع	$B_{k+1}s_k = y_k$	20
معادلة نيوتن	تحديد اتّجاه الخطوة	24
معيار نَوَوِي	مجموع القيم المفردة	34
مغلقة	محدّبة وأشباه متّصلة سفلياً	22
مقعّرة	$H(\lambda p + (1-\lambda)q) \geq \lambda H(p) + (1-\lambda)H(q)$	26
مُقوّب	رسم بين فئتين يحفظ البنية	47
مكمّل	تحقيق المساواة	28
منتظمة	تأهّل القيد (LICQ)	21
منظور	$tf(x/t)$	22
موجب محدّد	$d\theta^\top I d\theta > 0$	29
نات	الوحدة المعتادة هنا	26
نزع التحيز	طرح حدود الذات	42
نشط	قيد بـ $g_i = 0$	21
نظام التدريب الكسول	الميزات لا تتحرّك	40
نظام النواة	$\alpha = 1$ (كسول)	40
نظام تعلّم الميزات	$\alpha = 0$ (mean-field)	40
نقاء	إنتروبيا ورقة = 0 ⇒ نقية	26
نقطة الاستيعاب	$p \approx n$	34
نقطة ثابتة	$\sigma \in BR(\sigma)$	45
نقطة حرجة	$\nabla f = 0$	20
هافان	خوارزمية دمج متكرّرة	28
هبوط مزدوج	منحنى الخطر: هبوط ← ذروة ← هبوط	34
هوفدينغ	متراجحة التركيز (الفصل 17)	30
يعتمد على البيانات	ميزته الكبرى	31
a.s.	تقريباً يقيناً	13
Bayes	مبرهنة بايز	13
BIBO	محدود الدخل ⇒ محدود الخرج	53
block-inverse	معكوس كتلي	15
BR	مطابَق أفضل استجابة (كاكوتاني)	45
CFR	تقليف الندامة المضادّ	45
CRB	كرامير–راو	15
assignment credit	عَزو المكافأة للوكيل المسؤول	45
CRF	حقل شرطي عشوائي	16
d-separation	فصل-د	16
DAG	رسم بياني لا دوري موجّه	16
Elo	تقييم نسبيّ للاعبين	45
equivariance	الإزاحة تتبع الترتيب	43
ergodic	عريض	16
ERM	الخوارزمية الكافية	32
family exponential	العائلة الأسّية	16
استعلامات/Fano	أدوات الإثبات	32
Filtration	تسلسل المُعقّدات المتداخلة	46
Gibbs	توزيع غيبس	16
GN	غاوس-نيوتن	11
cover good	تقاطعات ذات اتّصال	46
GP	عقوبة التدرّج $(\|\nabla f\| - 1)^2$	42
HiPPO	تهيئة الضغط التاريخي	53
i.d.	بالتوزيع	13
i.p.	بالاحتمال	13

invariance	الثبات كلّياً	43
IS	حاصل الابتكار	41
Isomap	تضمين بـMDS على الجيوديسيّات	48
joint	التوزيع المشترك	16
K-FAC	تقريب طبقيّ لـF	48
Kleisli	فئة السهام $A \to T(B)$	47
lasso	L1	30
LayerNorm	تطبيع لكلّ عيّنة	39
LeakyReLU	تنشيط بمنحدر سالب صغير	43
Lipschitz	شرط انتظام	12
LOO	$k = n$	30
LOTUS	قانون الإحصائي النائم	15
MAD	وسيط الانحراف المطلق	52
MAP	أقصى لاحق	16
MCMC	مونت كارلو بالسلاسل	16
MDL	Length Description Minimum	28
MINE	تقدير MI بـ تعليميT	27
NE	تقاطع أفضل الاستجابات	45
NeRF	حقل إشعاعي عصبي	54
nerve	مُعقّد التقاطعات	46
node/edge	العنقود / تقاطع العناقيد	46
non-polynomial	غير كثيرة الحدود	35
NP-صعب	لا خوارزمية حدودية معروفة	32
OLA	إعادة التركيب بالجمع المتداخل	52
on-policy	SARSA (الهدف يتبع π)	44
oracle	حدٌّ أعلى مثالي	52
overfitting	وصف بيانات بلا وصف نموذج	28
Para	فئة السهام ذات المعاملات	47
PD	مخطط الاستمرار (بطاقة)	46
periodogram	مقدّر الطيف	51
PI	Improvement of Probability	25
qf	إعادة التعامد (قطبي/QR)	24
QPE	تقدير الطور الكمّي	54
R	ندامة تراكميّة	45
RFF	ميزات فوريه عشوائية	51
ridge	L2 / Tikhonov حيد	30
RK4	رونج-كوتا 4	12
softmax	الحالة الخاصة للتصنيف	26
SpecAugment	تكبير طيفي	53
sublinear	تعلّم $\Rightarrow R_T/T \to 0$	25
SURE	تقدير مخاطرة Stein	52
مقطوع SVD	إعادة الرتبة بعد الخطوة	24
UCB	Bound Confidence Upper	25
bound union	اتّحاد الاحتمالات	30
WL	اختبار تصفية الألوان	43

نهاية الملحق.

مسرد المصطلحات

الشعار: «للسمّةِ في لغتين وجهان — والفهرس يجمعهما.»

بُني هذا الفهرس من مصدرين داخل المتن نفسه: أزواج «مقابل عربي «(English) الواردة في العناوين والمصطلحات العريضة وجداول الرموز والنثر، وقوائم «المصطلحات الإنجليزية المقابلة» الختاميّة في كل فصل. المصطلحات التي يستعملها المتن بصيغتها الإنجليزيّة كما هي (أسماء خوارزميات وبروتوكولات) فُصلت في جدول مستقل في نهاية الملحق.

الإحصاء: 204 مصطلحاً ثنائيّ اللغة · 131 مصطلحاً يُستخدم بصيغته الإنجليزيّة.

A

المصطلح الإنجليزي	المقابل العربي	الفصول
Actor-Critic	الممثل–الناقد	44
adjoint	التدرج العكسي	12، 36
adjunction	مرافقة	47
Aliasing	التشويه الطيفي	51
AND	العطف	1
Coding Arithmetic	الترميز الحسابي	28
associator	المجمع	47
attained	ملغوم	29
authorities	السلطات	4
authority	سلطة	4

B

المصطلح الإنجليزي	المقابل العربي	الفصول
Base	الأساس	1
Inequality Bernstein's	متراجحة برنشتاين	17
Derivative-Free / Black-Box	التحسين الأسود	25
diagonal block	قطرية الكتل	4
Brenier	دالة محدبة	42

C

المصطلح الإنجليزي	المقابل العربي	الفصول
forgetting catastrophic	النسيان الكارثي	2
Capacity Channel	سعة القناة	28
Complement	المتمم	1
slackness complementary	الركود المكمل	21
compression	حدود الضغط	34
concave	مقعر	8
number condition	رقم الحالة	3، 4، 5، 6
independence conditional	تكييف	27
conditioning	التكييف	5، 6
conjugacy	شرط الترافق	5
conjugate	المترافق	22
exponents conjugate	أسين مترافقين	5
Conjunction	العطف	1
consensus	توافق تام	4، 12

consistency	التوافق	5
Continuous	الإنتروبيا التفاضلية	26
contraction	انكماشية	4
envelope convex	الغلاف المقعب	5
ConvNTK	النواة الالتفافية	40
convolution	الالتفاف	49
covariance	مصفوفة التغاير	4، 5
CRF	الحقول الشرطية	16
critic	الناقد	42
Cross-Attention	الانتباه المتقاطع	39
Cross-Entropy	إنتروبيا التقاطع	27

D

المصطلح الإنجليزي	المقابل العربي	الفصول
nodes dangling	العقد المعلقة	4
curation/augmentation data	تصميم البيانات	6
Laws Morgan's De	قوانين دي مورغان	1
Divergence Sinkhorn Debiased	العملي	42
Determinant	المحدد وخصائصه	3، 4
deterministic	خوارزميات حتمية	6، 40
dffiusion	الانتشار	12، 19
dilation	التوسيع	37، 53
stochastic doubly	مزدوجة العشوائية	5
drfit	الانحدار	19، 41

E

المصطلح الإنجليزي	المقابل العربي	الفصول
rank effective	الرتبة الفعالة	5
eigenvalue	قيمة ذاتية	4
eigenvector	متجه ذاتي	4
ELBO	الحد السفلي للدليل	18، 29، 41
embedding	التضمين	23، 38
embeddings	التضمينات	4، 5، 7
clause empty	التناقض	1
equivariance	التبدل	37
camera event	الكاميرا الحدثية	54
risk excess	الخطر الزائد	30
Improvement Expected	التحسين المتوقع	25

F

المصطلح الإنجليزي	المقابل العربي	الفصول
f-Divergences	تباعدات ف-ديفرجنس	27
Fenchel	الازدواج المترافق	22
Conjugate Fenchel	الازدواج المترافق	22
filtration	الترشيح	19
FNO	المؤثرات العصبية الفوريه	54
Forget/Input/Output	وبوابات النسيان	38
formula	صيغة	1
forward-mode	التفاضل الأمامي	36

G

المصطلح الإنجليزي	المقابل العربي	الفصول
GCN	الالتفاف البياني	43
Gordon	لامتساوية غوردون	5
clipping gradient	قص التدرج	2، 4، 17، 21
Network Attention Graph	الانتباه البياني	43
Grouped	ومجمع	37

H

المصطلح الإنجليزي	المقابل العربي	الفصول
Hann/Hamming/Blackman	النافذة	51
Momentum Heavy-Ball	الزخم الثقيل	23
Heine–Borel	متراصة	5
hop	القفزة	52
hub	مركز	4
hubs	المراكز	4
Coding Huffman	ترميز هافمان	28

I

المصطلح الإنجليزي	المقابل العربي	الفصول
IFF	التكافؤ	1
Principle Inclusion–Exclusion	مبدأ الشمول والاستبعاد	1
infinite	لانهائي	7
Product Inner	الضرب الداخلي	2، 5
INR/SIREN	التمثيلات الضمنية	54
quantization INT8/INT4	تكميم النماذج	4
Intersection	التقاطع	1
invariance	الثبات	37
invariant	ثابت	29
similarity under invariant	ثابتتان تشابهيا	4
refinement iterative	التنقيح التكراري	6

J

المصطلح الإنجليزي	المقابل العربي	الفصول
jump	قفزة	7

K

المصطلح الإنجليزي	المقابل العربي	الفصول
Formulation Kantorovich	صياغة كانتوروفيتش	42
space kernel/null	النواة	4
KKT	شروط كاروش–كون–تاكر	20، 21
Divergence KL	تباعد كولباك–لايبلر	27
Inequality Kraft	متراجحة كرافت	28

L

المصطلح الإنجليزي	المقابل العربي	الفصول
propagation label	انتشار التسميات	4
LayerNorm	وتطبيع الطبقة	39، 52
Learning Feature & Limitations	التعلم الميزاتي	40
Search Line	البحث الخطي	20
low-pass	مرور منخفض	4
LU/Cholesky	استخدم	3

M

المصطلح الإنجليزي	المقابل العربي	الفصول
hypothesis manfiold	فرضية المتعدد	2
Mapper	المخططات	46
margin	الهامش	34
Inequality Markov's	متراجحة ماركوف	17
masking	التعقيد والقناع	39
Induction Mathematical	مبدأ الاستقراء الرياضي	1
completion matrix	إكمال المصفوفات	4، 18
DCT / Fatou / MCT	مبرهنات التقارب	10
element measure	الإجراء	10
distance / metric	مسافة	5
Attention Multi-Head	تعدد الرؤوس	39
Information Mutual	المعلومات المتبادلة	26

N

المصطلح الإنجليزي	المقابل العربي	الفصول
Gradient Natural	التدرج الطبيعي	3، 11، 29
Negation	النفي	1
Gradient Accelerated Nesterov	تسريع نيستروف	23
LRT & Neyman–Pearson	اختبار الفرضيات	18
Norm	الناظم	5
margin / norm-based	الحدود المعيارية	34
Flows Normalizing	التدفقات التطبيعية	2، 14، 41
Norms	النواظم	4، 5
NOT	النفي	1
Novikoff	البرهان	35
NTK	نواة التماس العصبية	11، 34، 40

O

المصطلح الإنجليزي	المقابل العربي	الفصول
ODE	المعادلات التفاضلية العادية	12
one-hot	الهدف	36
operator	مشغل	5، 54
RNN orthogonal/unitary	الوحدوية	5
oscillatory	تذبذبي	7
overflow	فيضان	6

P

المصطلح الإنجليزي	المقابل العربي	الفصول
PAC-Bayes	حدود	34
padding	الحشو	37، 40
Sum Partial	المجموع الجزئي	49
PDE	المعادلات التفاضلية الجزئية	12
permutation	تبديلة	3، 43، 49
Dirichlet — Principle Pigeonhole	مبدأ الحمام	1
Processes Poisson	عمليات بواسون	19
pooling	التجميع	37، 43، 51، 54
prefix-free	فوري	28
prior	السابق	14، 16، 18
proper	صحيح	32
Proposition	القضية	1

Q

المصطلح الإنجليزي	المقابل العربي	الفصول
QSP/QFT	معالجة الإشارة الكمية	54

R

المصطلح الإنجليزي	المقابل العربي	الفصول
Rate–Distortion	نظرية معدل–التشويه	28، 54
realizable	تحققي	32
Field Receptive	الحقل الاستقبالي	37، 40، 53
Cell Recurrent	الخلية المتكررة	38
redundant	فائض	52
regular	منتظمة	29
regularizer	منتظما	1، 18
Forms Remainder	صيغ البقايا	11
removable	قابل للاختزال	7
Invariance Resolution	حياد للدقة	54
retraction	الانكماش	3، 24
triangle reverse	المتراجحة الفرقية	5
AD reverse-mode	التفاضل العكسي	36
ridge	التنظيم	2، 4، 6، 15، 16، 18، 30

S

المصطلح الإنجليزي	المقابل العربي	الفصول
saddle	نقطة سرجية	3
rules SAFE / screening safe	الفحص الآمن	5
scalars	قياسات	2
Scale	مقياس	52
scaling	تقييس الوحدات	6، 10، 14، 39
scattering	تحويل التشتت	52
Transform Scattering	تحويل التشتت	52
complement Schur	مكمل شور	3، 29
sefl-dual	ثنوي نفسه	5
seminorm	شبه ناظم	5
Series	المتسلسلة	49
SGD	الهبوط العشوائي	4، 5، 23، 34
shatter	تحطيم	31
Similarity	التشابه	3، 4
SIREN	يضبط الطيف	54
orthogonality soft	شبه متعامدة	6
soft-thresholding	عتبة لينة	4، 21، 50
Performer / Linformer / Sparse	الانتباه الفعال	39
Bias Spectral	التحيز الطيفي	50، 51، 54
clustering spectral	التجميع الطيفي	2، 4، 43، 54
normalization spectral	التطبيع الطيفي	2، 5
Spectrogram	المخطوط الطيفي	51، 52
Squeeze	نظرية الضغط	7
Stability	الاستقرار	6، 53
stationary/critical	نقطة حرجة	20
subgradient	التدرج الجزئي	5، 9، 20، 22
submultiplicativity	التضاعف التحتي	5
subnormal	دون المطبعة	6
Subspace	كمساحة فرعية	2، 4، 5، 24
summability	تجميع المتسلسلات	49
SVD	تحليل القيم المفردة	3، 4
SVG	رسم هندسي	4، 5، 6

T

المصطلح الإنجليزي	المقابل العربي	الفصول
Thresholding	العتبة	52
Trace	الأثر	3، 4، 5
translation	إزاحة	52
transpose	منقول	4

U

المصطلح الإنجليزي	المقابل العربي	الفصول
unfiorm	المنتظم	32
Union	الاتحاد	1
roundoff unit	وحدة التقريب	6

V

المصطلح الإنجليزي	المقابل العربي	الفصول
vacuous	فارغة	34
function variant	دالة تنازلية	1

W

المصطلح الإنجليزي	المقابل العربي	الفصول
Weierstrass	التعريف الرسمي	7
ZCA / Whitening	تبييض البيانات	4
case worst	عليا	6

أسماءٌ واسعة الانتشار تُكتب في الكتاب بالإنجليزية كما هي (خوارزميات، معايير، أسماء أعلام) — تُدرج هنا للمرجعيّة مع فصول ظهورها:

A

المصطلح الإنجليزي	الفصول
Summation Abel	49
Convergence Absolute	49
Filter Anti-alias	51
Complexity Attention	53

B

المصطلح الإنجليزي	الفصول
Basis	2
Inequality Bessel	49
Inversion Block	3
Butterfly	51

C

المصطلح الإنجليزي	الفصول
Inequality Cauchy–Schwarz	2
Summation Cesàro	49
Basis of Change	3
ChebNet	54
Test Comparison	49
Completeness	1
Series Fourier Complex	50
Convergence Conditional	49
Transform Wavelet Continuous	52
Test Convergence	49
Theorem Convolution	51
Cross-terms	52
Frequency Cutoff	53
Property Cyclic	3

D

المصطلح الإنجليزي	الفصول
Denoising	52
DFT	51
Filter Digital	53
Convolution Dilated	53
Dimension	2
Conditions Dirichlet	50
Kernel Dirichlet	50
Transform Wavelet Discrete	52
Downsampling	52
DTFT	51

E

المصطلح الإنجليزي	الفصول
Transformers Efficient	53
Sensing Event-Based	54

F

المصطلح الإنجليزي	الفصول
Kernel Fejér	50
FFT	51
Field	2
Bank Filter	52
FIR	53
Coefficients Fourier	50
Operator Neural Fourier	54
Series Fourier	50
Transform Fourier	51

G

المصطلح الإنجليزي	الفصول
Transform Gabor	52
Function Generating	49
Phenomenon Gibbs	50
Gram–Schmidt	2
Transform Fourier Graph	54
Processing Signal Graph	54

H

المصطلح الإنجليزي	الفصول
Uncertainty Heisenberg	52
Symmetry Hermitian	50
HiPPO	53

I

المصطلح الإنجليزي	الفصول
IIR	53
Range / Image	2
Representation Neural Implicit	54
Rules Inference	1
Test Integral	49
Transform Inverse	51

J

المصطلح الإنجليزي	الفصول
Jacobian	3
Discontinuity Jump	50

K

المصطلح الإنجليزي	الفصول
Space Null / Kernel	2
Product Kronecker	3

L

المصطلح الإنجليزي	الفصول
Spectrum Laplacian	54
Filter Learnable	53
Independence Linear	2
Map Linear	3

M

المصطلح الإنجليزي	الفصول
Inverse Matrix	3
Representation Matrix	3
Wavelet Mother	52
Analysis Multi-Resolution	52

N

المصطلح الإنجليزي	الفصول
Compression Neural	54
Operator Neural	54
Vocoder Neural	53
Neuromorphic	54
Rate Nyquist	51

O

المصطلح الإنجليزي	الفصول
Factor Orthogonal	3
Projection Orthogonal	2
Orthogonality	50
Basis Orthonormal	49
Overshoot	50

P

المصطلح الإنجليزي	الفصول
Identity Parseval	49
Identity Parseval's	50
Reconstruction Phase	53
Principle Pigeonhole	1
Convergence Pointwise	50
Decomposition Polar	3
Zeros & Poles	53
Factor Semidefinite Positive	3
Series Power	49
Density Spectral Power	51
Logic Predicate	1
Logic Propositional	1

Q

المصطلح الإنجليزي	الفصول
Decomposition QR	2
Transform Fourier Quantum	54
Processing Signal Quantum	54

R

المصطلح الإنجليزي	الفصول
Test Raabe	49
Convergence of Radius	49
Theorem Rank–Nullity	2
Test Ratio	49
Resolution	1
Rearrangement Riemann	49
Test Root	49

S

المصطلح الإنجليزي	الفصول
Theorem Sampling	51
Solver SAT	1
Speech Sefl-Supervised	53
Theory Set	1
Sherman–Morrison–Woodbury	3
Transform Fourier Short-Time	52
Interpolation Sinc	51
Soundness	1
Span	2
SpecAugment	53
Decay Spectral	50
Filtering Spectral	54
Leakage Spectral	51
Signals Spiking	54
Model State-Space	53
Lemma Exchange Steinitz	2

T

المصطلح الإنجليزي	الفصول
Resolution Time–Frequency	52
Function Transfer	53
Band Transition	53
Error Truncation	50

U

المصطلح الإنجليزي	الفصول
Convergence Unfiorm	49، 50

V

المصطلح الإنجليزي	الفصول
Space Vector	2
Vectorization	3

W

المصطلح الإنجليزي	الفصول
Wavelet	52
M-test Weierstrass	49
Wiener–Khinchin	51
Distribution Wigner–Ville	52
Windowing	51

Z

المصطلح الإنجليزي	الفصول
Z-transform	49

نهاية الملحق.