رياضيات
الذكاء الاصطناعي

من الأسس الرياضية إلى أحدث النظريات

مرجع أكاديمي شامل

تسعة أجزاء · أربعة وخمسون فصلاً · مئات النظريات والأمثلة

م/أحمد صالح المغز

تأليف

الطبعة الأولى

المحتويات

I الأسس الرياضية ١

١ المنطق الرياضي، نظرية المجموعات، وأسس البرهان ٣

٢ الفضاءات المتجهة، الاستقلال الخطي، والهندسة الداخلية ٤١

٣ المصفوفات والتحويلات الخطية ٧٩

٤ القيم الذاتية، تحليل القيم المفردة (SVD)، وتحليل المصفوفات ١١٧

٥ النواظم (Norms)، المسافات، ومتراجحات المصفوفات ٢١١

٦ التحليل العددي والاستقرار الحسابي ٢٩٣

II التفاضل والتكامل ٣٨٢

٧ النهايات والاتصال والتقارب ٣٨٤

٨ الاشتقاق وقواعده ٤٢٩

٩ التفاضل المصفوفي: اليعقوبية، الهِسّية، وقواعد السلسلة ٤٦٧

١٠ التكامل، نظرية القياس، وتكامل ليبيسغ–ستيلتjes ٥٠٣

١١ متفاضلة تايلور وتحليل الأخطاء ٥٤٤

١٢ المعادلات التفاضلية والنظم الديناميكية ٥٨٣

III الاحتمالات والإحصاء ٦٢٠

١٣ فضاءات الاحتمال وبُنى القياس ٦٢٢

١٤ المتغيرات العشوائية والتوزيعات القياسية ٦٥٩

١٥ المتوقّع، التباين، والمصفوفات الموجبة ٦٨٥

١٦ الاحتمال الشرطي المتقدّم، بايز، والحقول العشوائية ٧١١

١٧ متراجحات التركيز (Concentration Inequalities) ٧٣٩

١٨ الإستدلال الإحصائي وتقدير المعلمات (MLE) / (MAP) ٧٥٩

١٩ السلاسل الزمنية والعمليات العشوائية ٧٧٧

IV التحسين ٧٩٥

٢٠ التحسين غير المقيّد واختبارات الأمثلية ٧٩٧

٢١ التحسين المقيّد: KKT والثنائية ٨١٥

٢٢ التحسين المحدّب ونظرية الازدواج ٨٣٢

٢٣ خوارزميات التدرّج: SGD، الزخم، L-BFGS Adam، ٨٥٠

٢٤ التحسين على المتشعّبات (Riemannian Optimization) ٨٦٧

٢٥ التحسين التوزيعي والتحسين الأسود ٨٨٤

V نظرية المعلومات ٩٠٢

٢٦ الإنتروبيا، الإنتروبيا المشتركة، وكسب المعلومات ٩٠٤

٢٧ إنتروبيا التقاطع، تباعد KL، وتباعدات ف-ديفرجنس ٩٢١

٢٨ السعة، الترميز، ومبدأ الوصف الأقصر ٩٣٨

٢٩ الهندسة المعلوماتية وقياس فيشر ٩٥٦

VI نظرية التعلم الإحصائي ٩٨٥

٣٠ إطار التعلّم: ERM، SRM، والتحيز-التباين ٩٨٧

٣١ بُعد VC، متراجحات Rademacher، والتركيز ١٠١٤

٣٢ نظرية PAC والتعلّم القابل للتعلّم ١٠٤١

٣٣ الاستقرار الخوارزمي والتعميم ١٠٦٦

٣٤ حدود التعميم في الشبكات العميقة ١١٠٠

VII رياضيات الشبكات العصبية ١١٣٦

٣٥ البيرسيبترون، الشبكات الأمامية، ونظريات التقريب الشامل ١١٣٨

٣٦ الانتشار العكسي بوصفه تفاضلاً آلياً عكسياً ١١٦١

٣٧ الشبكات الالتفافية: الالتفاف، الطوبولوجيا، والتماثل ١١٨٢

٣٨ الشبكات المتكرّرة ورياضيات الزمن ١٢٠٢

٣٩ المحوّلات: الانتباه، الترميز الموضعيّ، والتعقيد ١٢٢١

٤٠ نواة التماس العصبية (Neural Tangent Kernel) ١٢٤٠

٤١ النماذج التوليدية (Generative Models) ١٢٦٠

٤٢ النقل الأمثل والمسافات المائية (Optimal Transport & Wasserstein) ١٢٧٩

VIII بنى متقدّمة ١٢٩٨

٤٣ نظرية الرسوم البيانية والشبكات العصبية البيانية ١٣٠٠

٤٤ التعلم التعزيزي: MDPs ومعادلات بيلمان وحدود العيّنات ١٣١٩

٤٥ نظرية الألعاب والتعلّم الاستراتيجي ١٣٣٨

٤٦ الطوبولوجيا وتحليل البيانات الطوبولوجي (TDA) ١٣٥٧

٤٧ نظرية الفئات والذكاء الاصطناعي التركيبي ١٣٧٥

٤٨ الهندسة التفاضلية في التعلّم: المتشعّبات والتمثيلات ١٣٩٣

IX المتسلسلات ومعالجة الإشارة ١٤١٢

٤٩ المتسلسلات: التقارب، المعايير، والدوال المولّدة ١٤١٤

٥٠ متسلسلة فوريه ونظرية التقريب ١٤٥٠

٥١ تحويل فوريه، العيّنات، ونظرية نيكويست–شانون ١٤٨٣

٥٢ التحليل الزمني-الترددي والمويجات ١٥١٨

٥٣ معالجة الإشارة الحديثة والتعلّم العميق على الإشارات ١٥٥١

٥٤ آفاق حديثة: إشارة الرسوم، المؤثّرات العصبية، والتمثيلات الضمنية ١٥٨٣

ا الفهرس الشامل ١٦١٦

ا مسرد المصطلحات ١٦٦٣

القسم I

الأسس الرياضية

نبذة عن هذا الجزء

قبل أن نسأل «كيف يتعلّم الحاسوب؟» لا بدّ من إتقان اللغة التي يُكتب بها الجواب. هذا الجزء يؤسّس تلك اللغة: من **المنطق والمجموعات** التي تصوغ المسألة، إلى **الفضاءات المتجهية** التي تسكنها البيانات، إلى **المصفوفات والتحويلات الخطية** التي تُنفَّذ بها كل عمليّة تعلّم عميقة فعليّاً، ثم **القيم الذاتية وتحليل SVD** التي تكشف البنية الكامنة، و**المعايير والمتراجحات** التي تضبط المسافات والأخطاء، وأخيراً **التحليل العددي** الذي يعلّمنا كيف يُنفَّذ كل ذلك على آلة محدودة الدقّة دون أن ينكسر الحساب. من يتقن هذا الجزء ملك مفردات الكتاب كله؛ كل فصلٍ لاحق سيستعير منه رمزاً أو متراجحة أو خدعة عدديّة. لا تقرأه قراءة سريعة: الأمثلة المحلولة فيه هي البذرة التي تنبت منها أمثلة الأجزاء الباقية. **فصول الجزء:** المنطق والمجموعات · الفضاءات المتجهية · المصفوفات والتحويلات الخطية · القيم الذاتية وSVD · المعايير والمتراجحات · التحليل العددي.

فصول هذا الجزء

- **الفصل 1.** المنطق الرياضي، نظرية المجموعات، وأسس البرهان
- **الفصل 2.** الفضاءات المتجهة، الاستقلال الخطي، والهندسة الداخلية
- **الفصل 3.** المصفوفات والتحويلات الخطية
- **الفصل 4.** القيم الذاتية، تحليل القيم المفردة (SVD)، وتحليل المصفوفات
- **الفصل 5.** النواظم (Norms)، المسافات، ومتراجحات المصفوفات
- **الفصل 6.** التحليل العددي والاستقرار الحسابي

المنطق الرياضي، نظرية المجموعات، وأسس البرهان

الشعار: «الذكاء الاصطناعي ليس سحراً؛ إنه حسابٌ على بنىً رمزية. والمنطق هو النحو الذي يُكتب به هذا الحساب.»

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. صياغة مسائل الذكاء الاصطناعي بلغة المنطق القضيوي والمجموعات.

٢. تطبيق **قوانين دي مورغان** لتبسيط الشروط المركّبة في الأنظمة الخبيرة والاستعلامات.

٣. استخدام **مبدأ الشمول والاستبعاب** في العدّ الاحتمالي وتغطية البيانات.

٤. بناء براهين صحيحة بـ **الاستقراء الرياضي** على خوارزميات التعلّم.

٥. استنتاج حدود دنيا مضمونة بـ **مبدأ الحمام** (وأثره في التعلّم والتجزئة).

٦. تركيب استدلالات آلية بـ **قواعد الاستدلال وقاعدة الاستيعاب**.

المتطلبات المسبقة

معرفة بحساب المجموعات الابتدائية. لا يُفترض أي معرفة مسبقة بالذكاء الاصطناعي.

خريطة الفصل

القسم	القانون/النظرية	عدد الأمثلة المحلولة
1.1	المنطق القضيوي والمجموعات — المفردات	—
2.1	قوانين دي مورغان	15
3.1	مبدأ الشمول والاستبعاد	15
4.1	مبدأ الاستقراء الرياضي	15
5.1	مبدأ الحمام (ديريكله)	15
6.1	قواعد الاستدلال والاستيعاب	15
7.1	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

Inclusion–Exclusion · Laws Morgan's De · Theory Set · Logic Predicate · Logic Propositional · Resolution · Rules Inference · Principle Pigeonhole · Induction Mathematical · Principle Solver SAT · Completeness · Soundness

1.1.1 القضية (Proposition)

القضية عبارة لغوية يمكن الحكم عليها بالصدق أو الكذب، ولا تحتمل الأمرين معاً.

$$P \in \{\text{True},\ \text{False}\} \equiv P \in \{1,\ 0\} \tag{1.0.1}$$

الرمز	المعنى	بديل برمجي
$P,\ Q,\ R$	قضايا (متغيّرات قضوية)	متغيّر منطقي bool
False / True	قيمتا الصدق	0 / 1
$\top$	الصدق الدائم (tautology)	true
$\bot$	الكذب الدائم (contradiction)	false
$\neg$	النفي (NOT)	!
$\wedge$	العطف (AND)	&&
$\vee$	الفصل الشامل (OR)	`
$\oplus$	الفصل الحصري (XOR)	^
$\rightarrow$	اللزوم المنطقي (IF...THEN)	fi
$\leftrightarrow$	التكافؤ (IFF)	==
$\equiv$	التكافؤ المنطقي الدائم	—
$\models$	اللزوم الدلالي (كل نموذج يُحقّق)	—
$\vdash$	اللزوم التركيبي (يُشتقّ بالقواعد)	—
Γ	مجموعة مقدمات (نظرية)	قاعدة معرفة
φ	صيغة (formula)	استعلام

تنبيه مهم: الفرق بين $\rightarrow$ و $\models$ جوهري في الذكاء الاصطناعي: $\psi \rightarrow \varphi$ صيغةٌ داخل المنطق، بينما $\Gamma \models \varphi$ **حكمٌ** على اللغة يقول: «كل نموذج يُحقّق Γ يُحقّق φ أيضاً». الأنظمة الخبيرة تعمل بـ $\Gamma \vdash \varphi$ (اشتقاق)، ونحن نريدها أن تكون أمينة أي $\Gamma \vdash \varphi \Rightarrow \Gamma \models \varphi$.

2.1.1 الرابط بين المنطق والمجموعات

كل قضية P تقابل مجموعة A_P هي «مجموعة العوالم/الحالات التي يكون فيها P صادقاً»:

$$A_P \ = \ \{\, \omega \in \Omega \ \mid \ P(\omega) = 1 \,\} \tag{2.0.1}$$

الرمز	المعنى
Ω	فضاء العيّنات/العوالم الممكنة (sample space)
ω	عالم/حالة مفردة
$\mid$	فاصل الشرط «بحيث أنّ»
$\in$	ينتمي إلى

ويقابل ذلك:

$$A_{P \wedge Q} = A_P \cap A_Q, \qquad A_{P \vee Q} = A_P \cup A_Q, \qquad A_{\neg P} = A_P^c = \Omega \setminus A_P \tag{3.0.1}$$

هذا «القاموس» هو ما يجعل قوانين المنطق وقوانين المجموعات وجهين لعملة واحدة.

3.1.1 لماذا يهمّ هذا الذكاء الاصطناعي؟

التطبيق	أين يظهر المنطق
تمثيل المعرفة (Knowledge Graphs)	حقائق ثلاثية + قواعد استدلال
التحقق الرسمي من النماذج (Model Checking)	صيغ زمنية على حالات النظام
محرّكات SAT/SMT	إرضاء صيغة قضيوية
الذكاء العصبي–الرمزي (Neuro-Symbolic)	تحويل القواعد إلى قيود في دالة الخسارة
أنظمة التوصية القائمة على القواعد	شروط مركّبة على سمات المستخدم
أمن السيبرانية (SIEM)	قواعد تنبيه متداخلة

صاغها: أوغستس دي مورغان (1806–1871). وهي اليوم حجر الأساس في تبسيط الدوائر الرقمية وتحويل الاستعلامات وتطبيع الصيغ في محرّكات SAT.

1.2.1 الصياغة الرسمية

الصيغة القضيوية:

$$\neg(P \wedge Q) \equiv (\neg P) \vee (\neg Q) \tag{1.1}$$

$$\neg(P \vee Q) \equiv (\neg P) \wedge (\neg Q) \tag{2.1}$$

الصيغة المجموعية:

$$\left(\bigcup_{i \in I} A_i\right)^c = \bigcap_{i \in I} A_i^c \tag{3.1}$$

$$\left(\bigcap_{i \in I} A_i\right)^c = \bigcup_{i \in I} A_i^c \tag{4.1}$$

الصيغة الكمّية (المنطق المحمول):

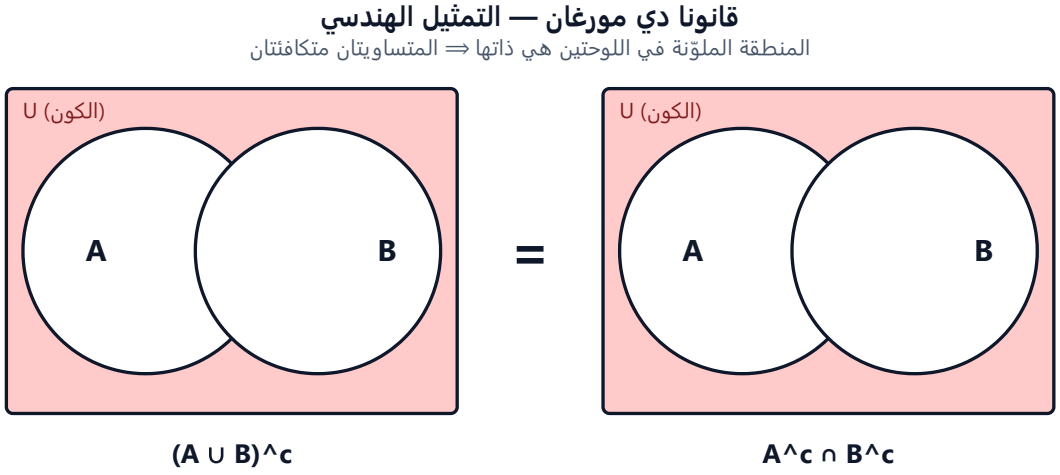
$$\neg\, \forall x\ P(x) \equiv \exists x\ \neg P(x) \tag{5.1}$$

$$\neg\, \exists x\ P(x) \equiv \forall x\ \neg P(x) \tag{6.1}$$

2.2.1 جدول الرموز والمعاملات (إلزامي)

الرمز	الاسم	المعنى الدقيق	ملاحظة تطبيقية
$\neg$	النفي (Negation)	يعكس قيمة الصدق: $0 \mapsto 1, 1 \mapsto 0$	بوابة NOT
$\wedge$	العطف (Conjunction)	صادق فقط إذا صدق الطرفان معاً	بوابة AND، تقابل $\cap$، وتقابل الضرب ab
$\vee$	الفصل (Disjunction)	صادق إذا صدق أحد الطرفين على الأقل	بوابة OR، تقابل $\cup$، وتقابل $a+b-ab$
$\equiv$	التكافؤ المنطقي	الصيغتان لهما جدول صدق متطابق	ليس عملية حسابية بل علاقة بين صيغتين
I	مؤشّر المجموعة (Index Set)	مجموعة الدلائل التي تُفهرس بها العائلة	قد تكون منتهية $\{1, \dots, n\}$ أو لانهائية
A_i	المجموعة رقم i	عنصر من عائلة المجموعات	في البرمجة: قائمة شروط
$\bigcup$	الاتحاد (Union)	كل ما ينتمي إلى **واحدة على الأقل**	OR" -ary$n$"
$\bigcap$	التقاطع (Intersection)	ما ينتمي إلى **كل** المجموعات معاً	AND" -ary$n$"
^{c} أو $\complement$	المتمّم (Complement)	$\Omega \setminus A$: كل ما ليس في A	على مستوى المجموعة NOT
$\forall$	كمّي شامل	«لكلّ»	حلقة all for
$\exists$	كمّي وجودي	«يوجد»	بحث حتى أول إصابة
$\setminus$	الطرح المجموعي	$A \setminus B = A \cap B^c$	«في A وليس في B»

3.2.1 الشكل الهندسي



شكل ١.١: *
قوانين دي مورغان

شكل (1.1): المنطقة الملوّنة (خارج كلا القرصين) هي متمّم الاتحاد في اللوحة اليسرى، وهي تقاطع المتمّمين في اليمنى. التساوي البصري هو البرهان الحدسي.

4.2.1 البرهان

البرهان الأول (بجدول الصدق) للقانون (1.1):

$(\neg P) \vee (\neg Q)$	$\neg Q$	$\neg P$	$\neg(P \wedge Q)$	$P \wedge Q$	Q	P
1	1	1	**1**	0	0	0
1	0	1	**1**	0	1	0
1	1	0	**1**	0	0	1
0	0	0	**0**	1	1	1

تطابق العمودين المُغلَّفين $\Longrightarrow$ التكافؤ.

البرهان الثاني (عنصري — يعمّم على أي عدد من المجموعات) للقانون (3.1):

نُثبت تساوي المجموعتين بإثبات تضمين مزدوج. ليكن x عنصراً في الكون Ω:

$$x \in \left(\bigcup_{i \in I} A_i\right)^c \iff x \notin \bigcup_{i \in I} A_i \iff \neg\big(\exists i \in I :\ x \in A_i\big) \iff \forall i \in I :\ x \notin A_i \iff \forall i \in I :\ x \in A_i^c$$

وإذن المجموعتان لهما العناصر ذاتها، فهما متساويتان. ■

5.2.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1.1-1): مرشّح البريد المزعج (Spam Filter)

المعطيات: قاعدة الحجب: «احجب الرسالة إذا احتوت كلمة «مجاني» و كان المرسل غير معروف». ليكن P = «الرسالة تحتوي «مجاني»»، Q = «المرسل غير معروف». المطلوب: صياغة شرط «الرسالة مقبولة» (أي لا تُحجب) بمفردات بسيطة، ثم حسابها إن كان $P = 1,\ Q = 0$.

الحل: الخطوة 1: شرط الحجب هو $P \wedge Q$. الخطوة 2: القبول هو نفي الحجب: $\neg(P \wedge Q)$. الخطوة 3: بتطبيق (1.1): $\neg(P \wedge Q) \equiv (\neg P) \vee (\neg Q)$. الخطوة 4: بالقيم المعطاة: $\neg P = 0$، $\neg Q = 1 \Longrightarrow 0 \vee 1 = 1$.

النتيجة: الرسالة **مقبولة** لأن المرسل معروف، حتى مع وجود كلمة «مجاني». الربط بالذكاء الاصطناعي: تجميع القواعد في مرشّح بيزي أو شجرة قرار يستلزم تحويل النفي إلى OR على المتمّمات لتقليل عدد الفروع.

مثال (2.1-1): كاميرا مراقبة ذكية

المعطيات: تبدأ الكاميرا التسجيل إذا اكتشفت حركة **أو** سمعت صوتاً غير اعتيادي: $H \vee S$. المطلوب: متى **لا** تسجّل؟

الحل: الخطوة 1: عدم التسجيل $= \neg(H \vee S)$. الخطوة 2: بتطبيق (2.1): $\neg(H \vee S) \equiv (\neg H) \wedge (\neg S)$. الخطوة 3: الترجمة: «لا حركة و لا صوت غير اعتيادي».

النتيجة: السكون التام بصرياً وسمعياً. الربط بالذكاء الاصطناعي: هذه الصيغة هي exactly ما يفعله دمج المستشعرات (sensor fusion) عند تعطيل الإنذارات الكاذبة، وتحويل OR إلى AND على النفي يقلّل استهلاك الطاقة على أجهزة الحافة.

مثال (3.1-1): السيارة ذاتية القيادة — قرار السير

المعطيات: تتوقف السيارة إذا وُجد مطر غزير و ضباب كثيف معاً: $M \wedge F$. تتوفّر مستشعرات تعطي $M = 1$ (مطر) و $F = 0$ (لا ضباب). المطلوب: هل تتوقف؟

الحل: الخطوة 1: التوقف $= M \wedge F = 1 \wedge 0 = 0$. الخطوة 2: السير $= \neg(M \wedge F) = (\neg M) \vee (\neg F) = 1 \vee 0 = 1$.

النتيجة: **تسير**. يكفي انتفاء شرط واحد. الربط بالذكاء الاصطناعي: أنظمة السلامة تبني «شجرة أعطال» (Fault Tree) حيث بوابة AND تعني «كل الأسباب معاً»، وبوابة OR تعني «أي سبب»؛ دي مورغان هو أداة التحويل بين شجرة الأعطال وشجرة النجاح.

مثال (4.1-1): استعلام قاعدة بيانات SQL

المعطيات: استعلام: SELECT * FROM users WHERE NOT (city='Cairo') AND (age>=18). جدول

فيه 1000 صف، منهم 300 في القاهرة، ومن هؤلاء 200 عمرهم ≥ 18. المطلوب: إعادة كتابة الاستعلام وعدد النتائج.

الحل: الخطوة 1: بالقانون (1.1): (A NOT) (NOT $\iff$ B) AND (NOT OR A) (B. الخطوة 2: أي WHERE age<18 OR city<>'Cairo'. الخطوة 3: عدد المستوفين للأصل: 200 − 300... لا، بل: المستثنون $|A \cap B| = 200$ =. الخطوة 4: النتائج $1000 - 200 = 800$ =.

النتيجة: 800 صف. الربط بالذكاء الاصطناعي: محسّنات الاستعلام (query optimizers) تُطبّق دي مورغان لدفع النفي إلى الداخل (push-down negation) فتستطيع استخدام الفهارس بدلاً من مسح الجدول كاملاً.

مثال (1.1-5): بوابة NAND العالمية

المعطيات: بوابة NAND تُعطي $\overline{a \cdot b}$. المطلوب: إثبات أن NAND وحدها تكفي لبناء NOT و OR.

الحل: الخطوة 1: $\text{NOT(a)} = \overline{a \cdot a} = \text{NAND(a,a)}$. الخطوة 2: بدي مورغان: $\overline{a \cdot b} = \bar{a} + \bar{b}$. الخطوة 3: إذن $a + b = \overline{\bar{a} \cdot \bar{b}} = \text{NAND}(\text{NAND(a,a)}, \text{NAND(b,b)})$. الخطوة 4: التحقق: إذا $a = 1, b = 0 \Longrightarrow$ NAND(1,1)=0، NAND(0,0)=1 $\Longrightarrow$ NAND(0,1)=1 = $a + b$ ✓.

النتيجة: NAND عالمية (Universal Gate). الربط بالذكاء الاصطناعي: كل دارة حسابية في المعالج — ومنها معجّلات الشبكات العصبية (TPU/NPU) — تُبنى من بوابة عالمية واحدة؛ هذا أصل « universality » في الحوسبة.

مثال (1.1-6): تشخيص طبي مركّب

المعطيات: يُشخَّص المريض بمتلازمة أيضية إذا كان اختبارا T_1 و T_2 **كلاهما** إيجابياً. نتائج مريض: T_1 = إيجابي، T_2 = سلبي. المطلوب: صياغة «المريض سليم بالنسبة للمتلازمة» بعدد أقل من العمليات الطبية.

الحل: الخطوة 1: التشخيص $T_1 \wedge T_2$ =. الخطوة 2: النفي $\neg T_1 \vee \neg T_2$ =. الخطوة 3: بما أن $\neg T_2 = 1$ (سلبي يكفي)، فالنتيجة 1 =.

النتيجة: سليم؛ ولا حاجة لإجراء اختبار ثالث. الربط بالذكاء الاصطناعي: «الاختبار المتسلسل» (sequential testing) في الأنظمة الخبيرة الطبية يعتمد على هذا: نفي AND يُقيَّم من اليسار لليمين ويتوقّف عند أول شرط منتفي (short-circuit evaluation).

مثال (1.1-7): نظام التحكم بالوصول RBAC

المعطيات: يُمنح المستخدم الصلاحية إذا كان (مديراً أو مالكاً للمورد) و (حسابه نشطاً): $(D \vee O) \wedge N$. مستخدم: $D = 0,\ O = 1,\ N = 1$. المطلوب: متى يُرفض الوصول؟

الحل: الخطوة 1: الرفض $\neg\big((D \vee O) \wedge N\big)$ =. الخطوة 2: بدي مورغان على AND الخارجي: $\neg(D \vee O) \vee \neg N$. الخطوة 3: ثم على OR الداخلي: $(\neg D \wedge \neg O) \vee \neg N$ =. الخطوة 4: للمستخدم: $\neg(D \vee O) = \neg(0 \vee 1) = 0$، $\neg N = 0 \Longrightarrow$ رفض 0 =.

النتيجة: يُمنح الوصول لأنه مالك وحسابه نشط. الربط بالذكاء الاصطناعي: محرّكات السياسات (OPA, XACML) تُطبّع الصيغ إلى DNF عبر دي مورغان قبل التقييم، فتصبح المقارنة بين السياسات مسألة تطابق أنماط.

مثال (1.1-8): محرّك بحث متقدّم

المعطيات: استعلام المستخدم: (python NOT java) OR (java في فهرس من 50,000 مستند: 12,000 فيها python، 9,000 فيها java، 3,000 فيهما معاً. المطلوب: عدد النتائج.

الحل: الخطوة 1: بالقانون (2.1): $\neg(P \vee J) \equiv \neg P \wedge \neg J$. الخطوة 2: عدد المستندات التي فيها أحدهما على الأقل (اتحاد): $|P \cup J| = 12{,}000 + 9{,}000 - 3{,}000 = 18{,}000$. الخطوة 3: النتائج $50{,}000 - 18{,}000 = 32{,}000$.

النتيجة: 32,000 مستند. الربط بالذكاء الاصطناعي: الفهارس المقلوبة (inverted indexes) تخزّن لكل مصطلح قائمة نشر (posting list)؛ الاستعلامات المنفية تُنفَّذ كتكملة لاتحاد القوائم، ودي مورغان يحوّل AND على النفي إلى طرح من الكون.

مثال (1.1-9): كشف احتيال بطاقة ائتمانية

المعطيات: يُرفع إنذار إذا كانت العملية (بمبلغ كبير و من بلد جديد) أو (خارج ساعات النشاط المعتادة): $(B \wedge N) \vee O$. عملية: $B = 1,\ N = 0,\ O = 0$. المطلوب: هل هناك إنذار؟ ثم اكتب صيغة «العملية طبيعية».

الحل: الخطوة 1: الإنذار $(1 \wedge 0) \vee 0 = 0 \vee 0 = 0$. الخطوة 2: الطبيعية $\neg\big((B \wedge N) \vee O\big) =$. الخطوة 3: بدي مورغان المزدوج: $\neg O \wedge (\neg B \vee \neg N) = \neg(B \wedge N) \wedge \neg O =$. الخطوة 4: بالقيم: $(\neg 1 \vee \neg 0) \wedge \neg 0 = 1 \wedge (0 \vee 1)$.

النتيجة: العملية طبيعية (مبلغ كبير لكن بلد معتاد وزمن معتاد). الربط بالذكاء الاصطناعي: تحويل القواعد إلى DNF يسمح بحساب «درجة الخطورة» كدرجة انتماء ضبابية (fuzzy membership) بدل المنطق الثنائي، باستبدال $\wedge$ بـ min و $\vee$ بـ max.

مثال (1.1-10): منظّم حرارة ذكي (IoT)

المعطيات: يُشغّل المكيّف إذا كانت (الحرارة > 28 أو الرطوبة > 70) و (أحدٌ في الغرفة): $C = (H \vee R) \wedge P$. الحالة: $H = 1,\ R = 0,\ P = 1$. المطلوب: حالة التشغيل، وصيغة الإيقاف.

الحل: الخطوة 1: $C = (1 \vee 0) \wedge 1 = 1$. الخطوة 2: الإيقاف $\neg C = \big(\neg H \wedge \neg R\big) \vee \neg P =$. الخطوة 3: بالقيم: $(0 \wedge 1) \vee 0 = 0$.

النتيجة: المكيّف **يعمل**. الربط بالذكاء الاصطناعي: في المنطق الضبابي تُستبدل الصيغة بـ $\mu_C = \min(\max(\mu_H, \mu_R),\ \mu_P)$؛ ودي مورغان يبقى صالحاً مع min/max لأنهما توزّعان على بعضهما.

مثال (1.1-11): التحقق الرسمي بمنطق الزمن الخطي (LTL)

المعطيات: الخاصية المطلوبة: «ليس صحيحاً أن النظام يبقى في الانتظار إلى الأبد و لا يستجيب أبداً»: $\neg(\Box W \wedge \Box\neg R)$. المطلوب: صياغة مكافئة مناسبة لخوارزمية التحقق.

الحل: الخطوة 1: بتطبيق (1.1): $\neg(\Box W \wedge \Box\neg R) \equiv \neg\Box W \vee \neg\Box\neg R$. الخطوة 2: $\neg\Box\varphi \equiv \Diamond\neg\varphi$ (نفي «دائماً» = «أحياناً النفي»). الخطوة 3: إذن الصيغة $\Diamond\neg W \vee \Diamond R =$. الخطوة 4: المعنى: «سيخرج من الانتظار في وقت ما، أو سيستجيب في وقت ما».

النتيجة: صيغة «أخيراً» (liveness) بدل «دائماً» (safety)، وهي أسهل للتحقق الآلي. الربط بالذكاء الاصطناعي: محرّكات التحقق (NuSMV, SPIN) تحوّل الخاصية إلى أوتوماتا Büchi؛ دي مورغان على مستوى $\Box/\Diamond$ هو نفسه على مستوى $\forall/\exists$ في (5.1)–(6.1).

مثال (1.1-12): روبوت مستودع — تجنّب العوائق

المعطيات: يتوقف الروبوت إذا وُجد عائق أمامه و عائق خلفه (محاصر): $F \wedge B$. قراءات الليدار: $F = 0,\ B = 1$. المطلوب: هل يتحرك؟ وإلى أين؟

الحل: الخطوة 1: التوقف $0 = 1 \wedge 0 =$. الخطوة 2: الحركة ممكنة $\neg(F \wedge B) = \neg F \vee \neg B = 1 \vee 0 = 1 =$. الخطوة 3: بما أن $\neg F = 1$ (لا عائق أمام)، الاتجاه الآمن هو **الأمام**.

النتيجة: يتحرك للأمام. الربط بالذكاء الاصطناعي: في التخطيط الرمزي، فضاء الحالة يُمثَّل بـ صيغة/BDD قضيوية؛ ودي مورغان هو عملية «التبديل بين تمثيل الحالات الممنوعة والسموحة بها».

مثال (1.1-13): نظام توصية بالمحتوى

المعطيات: يُستبعد الفيديو إذا كان (قصيراً و قديم): $O \wedge S$. مكتبة 200,000 فيديو، 40,000 قصير، 25,000 قديم، 12,000 قصير وقديم. المطلوب: عدد الفيديوهات المؤهّلة للترشيح.

الحل: الخطوة 1: المستبعد $|S \cap O| = 12{,}000 =$. الخطوة 2: المؤهّل $\neg(S \wedge O) \equiv \neg S \vee \neg O = \Longrightarrow$ العدد $200{,}000 - 12{,}000 =$. الخطوة 3: $188{,}000 =$.

النتيجة: 188,000 فيديو مؤهّل. الربط بالذكاء الاصطناعي: حساب «المرشّحين» (candidate generation) خطوةٌ تمهيدية لكل نموذج توصية؛ ودي مورغان يحوّل قواعد الاستبعاد من AND إلى OR على النفي فتُنفَّذ بفهارس بتّية (bitset OR).

مثال (1.1-14): شبكة عصبية تنفّذ بوابة NAND

المعطيات: بيرسيبترون: $y = \mathbb{1}[w_1x_1 + w_2x_2 + b \geq 0]$، بـ $w_1 = w_2 = -2,\ b = 3$. المطلوب: أي بوابة منطقية يُنفّذها؟ وما علاقتها بدي مورغان؟

الحل: الخطوة 1: جدول الحساب:

- $(0,0)$: $0+0+3=3\geq 0 \Longrightarrow y=1$
- $(1,0)$: $-2+3=1\geq 0 \Longrightarrow y=1$
- $(0,1)$: $-2+3=1\geq 0 \Longrightarrow y=1$
- $(1,1)$: $-4+3=-1<0 \Longrightarrow y=0$ الخطوة 2: هذا جدول $\neg(x_1\wedge x_2)$ = NAND. الخطوة 3: بدمج ثلاث خلايا NAND (انظر مثال 1.1-5) نبني OR و NOT.

النتيجة: خلية عصبية واحدة بوزن سالب وانحياز موجب = بوابة NAND = أساس أي حاسوب. الربط بالذكاء الاصطناعي: هذا هو المثال الأدنى على أن الشبكة العصبية **تحسب صيغاً منطقية**؛ ومنه تبدأ نظريات التقريب الشامل (الفصل 35).

مثال (1.1-15): جدولة تدريب على خوادم GPU

المعطيات: يُؤجَّل التدريب إذا كان (كلّ الـ GPU مشغولة **أو** الذاكرة المتوفّرة < 8GB): $G\vee M$. الحالة: $G=0$ (يوجد GPU فارغة)، $M=1$ (ذاكرة قليلة). المطلوب: هل يُشغَّل التدريب؟

الحل: الخطوة 1: التأجيل $=0\vee 1=1 \Longrightarrow$ **يُؤجَّل**. الخطوة 2: التشغيل $=\neg(G\vee M)=\neg G\wedge\neg M=1\wedge 0=0$. الخطوة 3: لتشغيله نحتاج تحرير ذاكرة (جعل $M=0$).

النتيجة: يبقى مؤجَّلاً حتى تُحرَّر الذاكرة. الربط بالذكاء الاصطناعي: موزّعات الأعمال (Kubernetes schedulers) تُقيّم «قيوداً» (predicates) بهذا الشكل؛ وتحويلها إلى DNF بدي مورغان يجعل فحص الجدوى متوازياً.

6.2.1 أخطاء شائعة

الخطأ	الصواب
$\neg(P\wedge Q)=\neg P\wedge\neg Q$	**العملية تتغيّر** — $\neg P\vee\neg Q$
نسيان قوسين: $\neg P\vee Q$ بدل $\neg(P\vee Q)$	القوسان يحدّدان مجال النفي
اعتبار $\neg\forall x P(x)\equiv\forall x\neg P(x)$	$\exists x\,\neg P(x)$
الخلط بين $\equiv$ (تكافؤ صيغ) و $\leftrightarrow$ (رابط داخل صيغة)	$\leftrightarrow$ رابط، $\equiv$ علاقة خارجية

الفكرة: إذا جمعت أحجام المجموعات «شمولاً» تكون قد حسبت التقاطعات مرتين، ف«تستبعدها»؛ ثم تكون قد استبعدت التقاطع الثلاثي أكثر من اللازم، فتعيده ... حتى تصل إلى دقة تامّة.

1.3.1 الصياغة الرسمية

مجموعتان:

$$|A\cup B| \;=\; |A|+|B|-|A\cap B| \tag{7.1}$$

ثلاث مجموعات:

$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C| \tag{8.1}$$

الصيغة العامة:

$$\left|\bigcup_{i=1}^{n} A_i\right| = \sum_{i=1}^{n} |A_i| - \sum_{1\le i<j\le n} |A_i \cap A_j| + \sum_{1\le i<j<k\le n} |A_i \cap A_j \cap A_k| - \cdots + (-1)^{n+1} \left|\bigcap_{i=1}^{n} A_i\right| \tag{9.1}$$

أو بصيغة مختصرة:

$$\left|\bigcup_{i=1}^{n} A_i\right| = \sum_{\emptyset \neq S \subseteq \{1,\ldots,n\}} (-1)^{|S|+1} \left|\bigcap_{i \in S} A_i\right| \tag{'9.1}$$

الصيغة الاحتمالية (تُستخدم أكثر في الذكاء الاصطناعي):

$$\mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \sum_{i} \mathbb{P}(A_i) - \sum_{i<j} \mathbb{P}(A_i \cap A_j) + \cdots + (-1)^{n+1} \mathbb{P}\left(\bigcap_{i} A_i\right) \tag{10.1}$$

متّراجحة بونفيروني (نتيجة مباشرة — تُستخدم لتقدير الحدود العليا والدنيا):

$$\sum_{i=1}^{n} \mathbb{P}(A_i) - \sum_{i<j} \mathbb{P}(A_i \cap A_j) \le \mathbb{P}\left(\bigcup_{i} A_i\right) \le \sum_{i=1}^{n} \mathbb{P}(A_i) \tag{11.1}$$

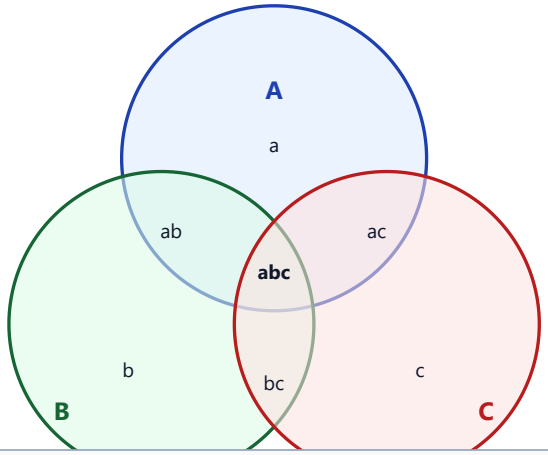
2.3.1 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
$\lvert A\rvert$	العدد الأصلي (Cardinality)	عدد عناصر المجموعة المنتهية	في الاحتمال يقابلها $\mathbb{P}(A)$
$\cup$	الاتحاد	«واحدة على الأقل»	$\vee$ منطقياً
$\cap$	التقاطع	«الكل معاً»	$\wedge$ منطقياً
$S \subseteq \{1,\ldots,n\}$	مجموعة فرعية من الدلائل	كل اختيار لمؤشّرات	عددها $2^n - 1$ حدّاً
$(-1)^{\lvert S\rvert+1}$	إشارة التصحيح	زوجي $\Rightarrow$ سالب، فردي $\Rightarrow$ موجب	سبب تسمية «الاستبعاد»
$\mathbb{P}(\cdot)$	الاحتمال	قياسٌ مجموعه 1 على Ω	انظر الفصل 13
$\sum_{i<j}$	مجموع على أزواج مرتّبة	عدد الحدود $\binom{n}{2}$	—
$\binom{n}{k}$	التوافيق	عدد اختيار k من n	$\frac{n!}{k!(n-k)!}$
في (11.1) $\le$	متّراجحة	حدّان: أدنى وأعلى	تُسمّى حدود بونفيروني

3.3.1 الشكل الهندسي

شكل (2.1): المنطقة abc (مثلث الوسط) تُحسب ثلاث مرات في $|A|+|B|+|C|$، وتُطرح ثلاث مرات في حدود الأزواج، فتُعاد مرة واحدة في الحدّ الأخير $\Rightarrow$ صافي مرة واحدة.

مبدأ الشمول والاستبعاد (ثلاث مجموعات)



$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|$$

شكل (1.2): كل منطقة تُحسب مرة واحدة بالضبط بعد التصحيح

شكل ٢.١: *
مبدأ الشمول والاستبعاد

4.3.1 البرهان (طريقة العدّ المزدوج)

لتكن x عنصراً يقع في **بالضبط** k مجموعة من المجموعات $A_1, \ldots, A_n$ (حيث $1 \le k \le n$). عدد المرات التي يُحسب بها x في الطرف الأيمن من (9.1):

$$N(x) = \binom{k}{1} - \binom{k}{2} + \binom{k}{3} - \cdots + (-1)^{k+1}\binom{k}{k} = \sum_{j=1}^{k} (-1)^{j+1}\binom{k}{j}$$

من ذي الحدين (نظرية نيوتن):

$$\sum_{j=0}^{k} (-1)^j \binom{k}{j} = (1-1)^k = 0 \implies \sum_{j=1}^{k} (-1)^{j+1}\binom{k}{j} = \binom{k}{0} = 1$$

أي أن كل عنصر في الاتحاد يُحسب **مرة واحدة بالضبط**، وكل عنصر خارج الاتحاد ($k = 0$) يُحسب صفر مرة. فالطرفان متساويان. ■

5.3.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-2.1): طلاب ولغات برمجة

المعطيات: 120 طالباً؛ 70 يعرفون Python (A)، 55 يعرفون Java (B)، 30 يعرفون الاثنتين. المطلوب: من لا يعرف أيّاً منهما؟

الحل: الخطوة 1: $|A \cup B| = 70 + 55 - 30 = 95$. الخطوة 2: الخارج $= 120 - 95 = 25$.

النتيجة: 25 طالباً. الربط بالذكاء الاصطناعي: حساب «حجم السوق/الفئة المستهدفة» لمهارات نموذجية؛ نفس الحساب يُستخدم لتقدير حجم «مجموعة البيانات المفيدة» عند دمج مصادر متعدّدة.

مثال (1.2-2): ثلاثة أعراض وتشخيص

المعطيات: 1000 مريض: حمّى $|F| = 400$، سعال $|C| = 350$، ضيق نفس $|D| = 200$؛ $|F \cap C| = 150$، $|F \cap D| = 80$، $|C \cap D| = 60$، $|F \cap C \cap D| = 30$. المطلوب: كم مريضاً لديه عرضٌ واحد على الأقل؟

الحل: الخطوة 1: المجموع الفردي $= 400 + 350 + 200 = 950$. الخطوة 2: طرح الأزواج $= 950 - (150 + 80 + 60) = 950 - 290 = 660$. الخطوة 3: إضافة الثلاثي $= 660 + 30 = 690$.

النتيجة: 690 مريضاً (69%). الربط بالذكاء الاصطناعي: في أنظمة الفرز (triage) يحدّد هذا «معدّل التفعيل» لقاعدة مركّبة، وهو ما يضبط حساسية النموذج مقابل عبء العمل السريري.

مثال (1.2-3): وسوم المستندات في محرّك بحث

المعطيات: 5000 مستند: موسومة ML = 1200، Vision = 900، NLP = 800؛ ML∩Vision = 300، ML∩NLP = 250، Vision∩NLP = 150؛ الثلاثي = 70. المطلوب: عدد المستندات الموسومة بواحد على الأقل من الوسوم الثلاثة.

الحل: الخطوة 1: $2900 = 800 + 900 + 1200$. الخطوة 2: $2200 = 2900 - 700 = 2900 - (300 + 250 + 150)$. الخطوة 3: $2270 = 2200 + 70$.

النتيجة: 2270 مستنداً $\Longrightarrow$ 2730 مستنداً غير موسومة. الربط بالذكاء الاصطناعي: تقدير حجم «الشريحة المؤهّلة للتدريب» (eligible training pool) قبل بناء مجموعة بيانات متعددة الوسوم.

مثال (1.2-4): صلاحيات المستخدمين في نظام سحابي

المعطيات: 800 مستخدم: لهم دور read = 600، write = 350، admin = 100؛ read∩write = 300، read∩admin = 90، write∩admin = 60؛ الثلاثي = 55. المطلوب: كم مستخدم له صلاحية واحدة على الأقل؟

الحل: الخطوة 1: $1050 = 600 + 350 + 100$. الخطوة 2: $600 = 1050 - 450 = 1050 - (300 + 90 + 60)$. الخطوة 3: $655 = 600 + 55$.

النتيجة: 655 من 800 (81.9%). الربط بالذكاء الاصطناعي: حساب «سطح الهجوم» (attack surface) = اتحاد الصلاحيات، هذا مقياس مباشر للمخاطر في أمن الذكاء الاصطناعي.

مثال (1.2-5): تغطية شبكة مستشعرات زراعية

المعطيات: حقل مقسّم لمناطق، ثلاثة مستشعرات تغطي: A: 40%، B: 35%، C: 30% من المساحة، التداخلات: 12%، 10%، 8%؛ الثلاثي 4%. المطلوب: نسبة المساحة المغطّاة فعلياً.

الحل: الخطوة 1: $105 = 30 + 35 + 40$. الخطوة 2: $75 = 105 - 30 = 105 - (12 + 10 + 8)$. الخطوة 3: $79 = 75 + 4$.

النتيجة: 79% مغطّاة، 21% ثغرة blind). الربط بالذكاء الاصطناعي: «تغطية فضاء الميزات» spot) بمجموعة نماذج/نماذج أولية (prototypes)؛ الثغرة تُترجم إلى مناطق قرار غير موثوقة (out-of-distribution).

مثال (١.٢-6): احتمال فشل نظام موزّع

المعطيات: خدمة من 3 وحدات، احتمالات الفشل المستقلّة: 0.02، 0.03، 0.05. المطلوب: احتمال فشل الخدمة (فشل وحدة واحدة على الأقل).

الحل: الخطوة 1: بالاستقلال: $\mathbb{P}(A \cap B) = 0.02 \times 0.03 = 0.0006$؛ وبالمثل 0.001 و 0.0015؛ والثلاثي 0.00003. الخطوة 2: بالصيغة (١.١٠): $0.10 = 0.02 + 0.03 + 0.05$. الخطوة 3: $0.0969 = 0.10 - 0.0031 = 0.10 - (0.0006 + 0.001 + 0.0015)$. الخطوة 4: $+0.00003 = 0.09693$.

النتيجة: $\approx$ 9.٦٩% (مقابل 10% بالتقدير الساذج). الربط بالذكاء الاصطناعي: موثوقية أنظمة الاستدلال الموزّعة (inference clusters)؛ الفرق بين 10% و 9.٦٩% يحدّد عدد النسخ الاحتياطية المطلوبة.

مثال (١.٢-7): تصفية مجموعة تدريب بشروط متعددة

المعطيات: 100,000 صورة، معايير القبول: وضوح (A) 82,000، توازن لوني (B) 74,000، خلوّ من الوسوم الخاطئة (C) 90,000، الأزواج: 62,000 و 75,000 و 68,000، الثلاثي 58,000. المطلوب: حجم مجموعة التدريب النهائية.

الحل: الخطوة 1: $82{,}000 + 74{,}000 + 90{,}000 = 246{,}000$. الخطوة 2: $246{,}000 - 205{,}000 = 41{,}000 = -(62{,}000 + 75{,}000 + 68{,}000)$. الخطوة 3: $+58{,}000 = 99{,}000$.

النتيجة: 99,000 صورة صالحة (99%). الربط بالذكاء الاصطناعي: هذه هي «بوابة الجودة» في خطوط إنتاج البيانات (data pipelines)؛ إهمال حدّ التقاطع الثلاثي هو سبب كلاسيكي لانكماش مفاجئ في حجم البيانات.

مثال (١.٢-8): عدد مستندات تحتوي كلمة في استعلام OR

المعطيات: فهرس 2,000,000 مستند، «ذكاء» في 40,000، «اصطناعي» في 55,000، «تعلّم» في 30,000، الأزواج 8,000 و 5,000 و 6,000، الثلاثي 1,500. المطلوب: عدد نتائج الاستعلام ذكاء OR اصطناعي OR تعلّم.

الحل: الخطوة 1: $125{,}000 = 30{,}000 + 55{,}000 + 40{,}000$. الخطوة 2: $106{,}000 = 125{,}000 - 19{,}000 = -(8{,}000 + 5{,}000 + 6{,}000)$. الخطوة 3: $+1{,}500 = 107{,}500$.

النتيجة: 107,500 مستند. الربط بالذكاء الاصطناعي: حساب «التذكير الأقصى» (recall ceiling) لمحرّك استرجاع؛ لا يمكن لنموذج إعادة ترتيب (reranker) أن يتجاوز هذا السقف.

مثال (١.٢-9): تداخل مجموعات الميزات بين نموذجين

المعطيات: نموذج A يستخدم 500 ميزة، نموذج B يستخدم 400، نموذج C يستخدم 300، التداخل $A \cap B = 200$، $A \cap C = 120$، $B \cap C = 90$، الثلاثي 50. المطلوب: عدد الميزات الفريدة المستخدمة في المجموعة بأكملها.

الحل: الخطوة 1: $1200 = 300 + 400 + 500$. الخطوة 2: $790 = 1200 - 410 = (90 + 120 + 200)-$. الخطوة 3: $840 = 50+$.

النتيجة: 840 ميزة فريدة. الربط بالذكاء الاصطناعي: حساب «بصمة الذاكرة» عند دمج نماذج (model ensemble) أو عند حساب تعقيد استخراج الميزات في خط الأنابيب.

مثال (1.2-10): حملة تسويقية متعددة القنوات

المعطيات: 200,000 عميل وصلتهم: بريد (E) 90,000، رسالة نصية (S) 70,000، إشعار تطبيق (P) 60,000، الأزواج 30,000 و 25,000 و 20,000، الثلاثي 10,000. المطلوب: عدد العملاء الذين وصلتهم رسالة واحدة على الأقل، ونسبة الوصول الفريد.

الحل: الخطوة 1: $220{,}000 = 60{,}000 + 70{,}000 + 90{,}000$. الخطوة 2: $145{,}000 = 220{,}000 - 75{,}000 = (30{,}000 + 25{,}000 + 20{,}000)-$. الخطوة 3: $155{,}000 = 10{,}000+$. الخطوة 4: النسبة $= 155{,}000/200{,}000 = 77.5\%$.

النتيجة: 155,000 عميل (77.5%). الربط بالذكاء الاصطناعي: «الوصول الفريد» (unique reach) هو المقياس الحقيقي لتأثير الحملة؛ الجمع الساذج 220,000 يضخّم النتيجة بنسبة 42%.

مثال (1.2-11): تغطية الاختبارات البرمجية لنموذج

المعطيات: ثلاثة أجنحة اختبار تغطي وحدات الكود: 65%، 55%، 45%؛ تداخل الأزواج 30%، 25%، 20%؛ الثلاثي 15%. المطلوب: التغطية الإجمالية.

الحل: الخطوة 1: $165 = 45 + 55 + 65$. الخطوة 2: $90 = 165 - 75 = (20 + 25 + 30)-$. الخطوة 3: $105 = 15+$.

النتيجة: 105% $\Longrightarrow$ غير ممكن $\Longrightarrow$ البيانات متناقضة؛ الحد الأقصى 100%، فيلزم تصحيح القياسات (أو أن «النسبة المئوية» ليست من الكلّ نفسه). الربط بالذكاء الاصطناعي: **درس منهجي:** نتيجة خارج $[0, 1]$ لأي احتمال/نسبة تعني خطأً في المعطيات أو انتهاكاً لافتراض الاستقلال؛ هذه «فحص صحّة» (sanity check) إلزامي قبل أي حساب احتمالي.

مثال (1.2-12): خلاف نماذج في مجموعة (Ensemble Disagreement)

المعطيات: ثلاثة مصنّفات على 10,000 عيّنة: أخطاء A = 800، B = 900، C = 750؛ يتفق اثنان على الخطأ: $|A \cap B| = 300$، $|A \cap C| = 250$، $|B \cap C| = 280$؛ ثلاثتهم يخطئ معاً = 120. المطلوب: كم عيّنة يخطئ فيها واحد على الأقل؟

الحل: الخطوة 1: $2450 = 750 + 900 + 800$. الخطوة 2: $1620 = 2450 - 830 = (280 + 250 + 300)-$. الخطوة 3: $1740 = 120+$.

النتيجة: 1740 عيّنة (17.4%) $\Longrightarrow$ دقة التصويت بالأغلبية أعلى بكثير من أي نموذج مفرد. الربط بالذكاء الاصطناعي: هذا هو التفسير الكمّي لسبب نجاح التجميع (ensembling): الخطأ المشترك (التقاطعات) يجب أن يكون صغيراً مقابل الأخطاء الفردية.

مثال (1.2-13): تصنيف متعدد الوسوم للصور

المعطيات: 50,000 صورة: «شخص» 22,000، «سيارة» 18,000، «مبنى» 15,000؛ الأزواج 7,000 و 5,000 و 4,000؛ الثلاثي 2,000. المطلوب: عدد الصور التي تحمل وسماً واحداً على الأقل، ثم عدد الصور بوسم واحد **بالضبط**.

الحل: الخطوة 1: الاتحاد $= |A| + |B| + |C| - 2(|A \cap B| + |A \cap C| + |B \cap C|) + 3|A \cap B \cap C| = 55{,}000 - 2(16{,}000) + 3(2{,}000) = 55{,}000 - 32{,}000 + 6{,}000 = 29{,}000$. الخطوة 2: وسم واحد بالضبط $= 41{,}000 - 2{,}000 - 16{,}000 + 2{,}000 = 55{,}000$. الخطوة 3: النتيجة: 41,000 بوسم واحد على الأقل؛ 29,000 بوسم واحد بالضبط. الربط بالذكاء الاصطناعي: التمييز بين «once» و«at least once» هو نفسه التمييز بين دقة الوسم الجزئي والكلي (exact vs. partial) في تقييم التصنيف متعدد الوسوم.

مثال (1.2-14): تعداد n-grams في نموذج لغة

المعطيات: متن من 1,000,000 كلمة؛ القاموس يحتوي 60,000، 400,000 uni-gram، 900,000 bi-gram، tri-gram. التداخل بين الفئات (كمجموعات أنماط) مهمل، لكن داخلياً: 1,200,000 نمطاً محتملاً. استخدم حدّ بونفيروني لتقدير احتمال أن يظهر نمطٌ غير مرئي في الاختبار إن كان احتمال ظهور كل نمط 10^{-8} وعدد الأنماط 10^6. المطلوب: حدّ أعلى لاحتمال الظهور.

الحل: الخطوة 1: ليكن A_i حدث «النمط i يظهر». الخطوة 2: بحدّ الاتحاد (بونفيروني الأعلى من (1.1.11)): $\mathbb{P}(\cup A_i) \le \sum_i \mathbb{P}(A_i)$. الخطوة 3: $= 10^6 \times 10^{-8} = 10^{-2} = 0.01$. النتيجة: احتمال $\le 1\%$. الربط بالذكاء الاصطناعي: حدّ الاتحاد (union bound) هو الأداة الأساسية في حدود التعميم في التعلّم الآلي: $\mathbb{P}(\text{أيّ انحراف}) \le \sum \mathbb{P}(\text{انحراف}_i)$. سيظهر مجدداً في الفصل 32.

مثال (1.2-15): كشف تهديدات عبر ثلاثة مستشعرات أمنية

المعطيات: ثلاثة كواشف: إنذارات كاذبة في 5%، 4%، 6% من الأحداث (n = 100,000 حدث يومياً)؛ تكرار الإنذار الكاذب المشترك: 1,000 و 1,200 و 900 والثلاثي 200. المطلوب: عدد الإنذارات الكاذبة المميّزة يومياً.

الحل: الخطوة 1: $6{,}000 + 4{,}000 + 5{,}000 = 15{,}000$. الخطوة 2: $15{,}000 - (1{,}000 + 1{,}200 + 900) = 11{,}900$. الخطوة 3: $12{,}100 = 200 + 3{,}100$.

النتيجة: 12,100 إنذاراً كاذباً يومياً بدل 15,000 بالحساب الساذج (تحسّن 19%). الربط بالذكاء الاصطناعي: إزالة التكرار (deduplication) في أنظمة SIEM يقلّل «إرهاق التنبيهات» (alert fatigue) وهو شرط عملي لاعتماد نموذج كشف التهديدات.

6.3.1 أخطاء شائعة

الخطأ	الصواب
نسيان إضافة التقاطع الثلاثي في (8.1)	الإشارة تتناوب دائماً: $+, -, +, -, \ldots$
تطبيق الصيغة على أحداث غير منتهية العدد	الصيغة مشروطة بنهاية n (والا تقارب)
استخدام $\lvert A\rvert + \lvert B\rvert$ لحدثين غير متنافيين	غير متنافية $\Rightarrow$ اطرح التقاطع
نتيجة > 1 للاحتمال أو $> 100\%$ لنسبة	يُعيد فحص المعطيات فوراً

الفكرة: لإثبات صواب عبارة عن كل عدد طبيعي، يكفي إثبات أمرين: أنها صحيحة عند البداية، وأن صحتها عند أي مرتبة تستلزم صحتها عند المرتبة التالية. السلسلة كلها تسقط كقطع الدومينو.

1.4.1 الصياغة الرسمية

الاستقراء الضعيف (Weak Induction): لتكن $P(n)$ عبارةً قضيوية معرّفة على $n \geq n_0$.

$$\Big[\, P(n_0) \text{ صادقة} \,\Big] \;\wedge\; \Big[\forall k \geq n_0 :\; P(k) \Rightarrow P(k+1)\Big] \;\Longrightarrow\; \Big[\forall n \geq n_0 :\; P(n)\Big] \tag{12.1}$$

بصيغة مختصرة:

$$\big(P(n_0) \wedge \forall k \geq n_0\, [P(k) \to P(k+1)]\big) \;\Longrightarrow\; \forall n \geq n_0\; P(n) \tag{'12.1}$$

الاستقراء القوي (Strong Induction):

$$\Big[\forall k \geq n_0 :\; \big(\forall j :\; n_0 \leq j < k \Rightarrow P(j)\big) \Rightarrow P(k)\Big] \;\Longrightarrow\; \Big[\forall n \geq n_0 :\; P(n)\Big] \tag{13.1}$$

الاستقراء البنيوي (Structural Induction) — أساس إثبات صحة خوارزميات الأشجار والرسوم:

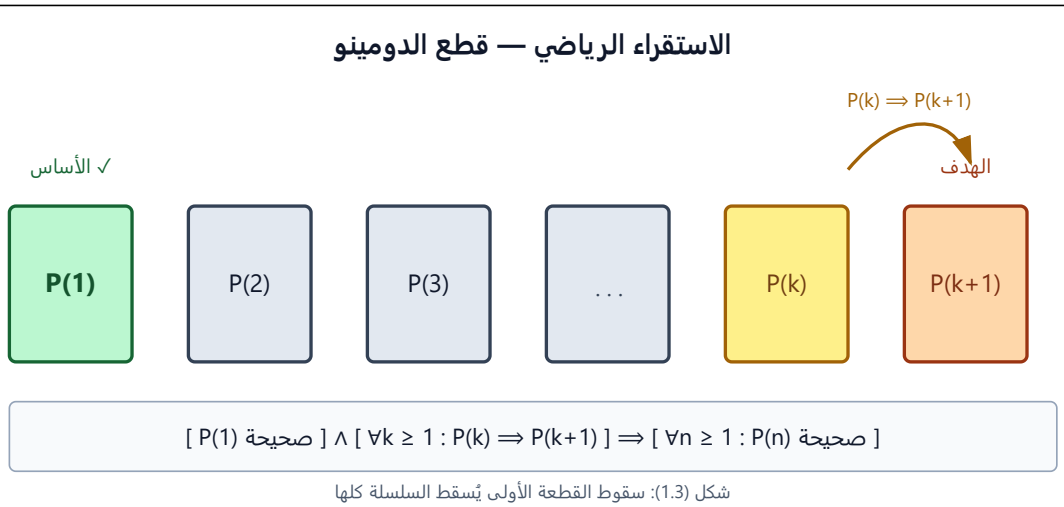
$$\Big[\, P \text{ كل ورقة تحقق} \,\Big] \;\wedge\; \Big[\forall v \text{ عقدة} :\; \big(\forall c \text{ من أبناء } v :\; P(c)\big) \Rightarrow P(v)\Big] \;\Longrightarrow\; \forall \text{عقدة} :\; P \tag{14.1}$$

مبدأ حسن الترتيب (Well-Ordering) — المبدأ المكافئ للاستقراء:

$$\forall S \subseteq \mathbb{N},\; S \neq \emptyset \;\Longrightarrow\; \exists m \in S :\; \forall s \in S,\; m \leq s \tag{15.1}$$

2.4.1 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
$P(n)$	العبارة/الخاصية	دالة من $\mathbb{N}$ إلى $\{0,1\}$	« predicate »
n_0	الأساس (Base)	أول قيمة تُثبت يدوياً	غالباً 0 أو 1
k	مرتبة الاستقراء	القيمة المفترض صحتها	«فرضية الاستقراء» IH
$\Rightarrow$	اللزوم	إذا صدق الأيسر صدق الأيمن	منطقياً $\to$
$\wedge$	العطف	كلا الشرطين معاً	شرطان لازم ومجموعهما كافٍ
$\mathbb{N}$	الأعداد الطبيعية	$\{0,1,2,\ldots\}$ أو $\{1,2,\ldots\}$ حسب الاصطلاح	—
$j < k$	—	كل المراتب السابقة	الفرق الجوهري بين (12.1) و (13.1)
S	مجموعة فرعية من $\mathbb{N}$	في (15.1): مجموعة «القيم المضادّة»	أداة البرهان بالتناقض
$T(n)$	دالة التكلفة	زمن/عدد عمليات خوارزمية على مدخل حجمه n	في تحليل التعقيد
$O(\cdot)$	ترميز O الكبير	حدّ أعلوى مقاربي	انظر الفصل 6



شكل (1.3): سقوط القطعة الأولى يُسقط السلسلة كلها

شكل ٣.١: *
الاستقراء الرياضي

3.4.1 الشكل الهندسي

شكل (3.1): القطعة الخضراء $(P(1))$ هي الأساس؛ السهم الذهبي هو خطوة الاستقراء؛ وكل قطعة لاحقة تسقط بالضرورة.

4.4.1 البرهان (من مبدأ حسن الترتيب)

نُثبت (12.1) بالتناقض. لنفرض أن المقدّمة صادقة ولكن التيجة كاذبة، أي توجد قيمة لا تحقق P. عرّف:

$$S \;=\; \{\, n \geq n_0 \mid P(n) \text{ كاذبة} \,\} \neq \emptyset$$

بمبدأ حسن الترتيب (15.1) يوجد أصغر عنصر $m = \min S$.

- $m \neq n_0$ لأن $P(n_0)$ صادقة (الأساس).
- إذن $m > n_0$، فليكن $k = m - 1 \geq n_0$. وبما أن m هو الأصغر في S، فـ $k \notin S$، أي $P(k)$ صادقة.
- بخطوة الاستقراء: $P(k) \Rightarrow P(k+1) = P(m)$، أي $P(m)$ صادقة $\Longrightarrow m \notin S$. تناقض.

إذن $S = \emptyset$، أي $P(n)$ صادقة لكل $n \geq n_0$. ■

5.4.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-3.1): عدد المعلمات في شبكة عصبية متعددة الطبقات

المعطيات: شبكة ذات L طبقات كاملة الاتصال؛ الطبقة ℓ فيها n_ℓ عصبون، ومدخلاتها $n_{\ell-1}$. معلمات الطبقة: $n_\ell n_{\ell-1} + n_\ell$ (أوزان + انحيازات). المطلوب: إثبات بالاستقراء أن العدد الكلي $W_L = \sum_{\ell=1}^{L}(n_\ell n_{\ell-1} + n_\ell)$.

الحل: الخطوة 1 (الأساس $L = 1$): $W_1 = n_1 n_0 + n_1$ ✓ بديهي. الخطوة 2 (الفرض): نفترض $W_k = \sum_{\ell=1}^{k}(n_\ell n_{\ell-1} + n_\ell)$. الخطوة 3 (الخطوة): بإضافة الطبقة $k+1$: $W_{k+1} = W_k + (n_{k+1}n_k + n_{k+1}) = \sum_{\ell=1}^{k+1}(n_\ell n_{\ell-1} + n_\ell)$ ✓. الخطوة 4: بالاستقراء، الصيغة صحيحة لكل $L \geq 1$.

النتيجة: عدد المعلمات الكلي يُحسب بجمع طبقي بسيط. الربط بالذكاء الاصطناعي: هذه الصيغة هي نواة أي حاسبة لمعلمات النموذج (مثل torchsummary)؛ وتُستخدم لتقدير بصمة الذاكرة قبل التدريب.

مثال (1.3-2): صحة خوارزمية ترتيب بالإدراج (Insertion Sort)

المعطيات: $P(n)$ = «الترتيب بالإدراج يُرتّب أي مصفوفة طولها n تصاعدياً». المطلوب: إثبات بالاستقراء.

الحل: الخطوة 1 (الأساس $n = 1$): مصفوفة من عنصر واحد مرتّبة دائماً ✓. الخطوة 2 (الفرض): الخوارزمية ترتّب أي مصفوفة طولها k. الخطوة 3 (الخطوة): لمصفوفة طولها $k + 1$: تُرتَّب أول k عناصر (بالفرض)، ثم يُدخل العنصر $(k+1)$ في موضعه الصحيح بمقارنات متتالية نحو اليسار حتى يصبح المقطع كله مرتّباً. الخطوة 4: إذن $P(k+1)$ صحيحة.

النتيجة: الخوارزمية صحيحة لكل n. الربط بالذكاء الاصطناعي: هذه هي حجة «المتغيّر الثابت للحلقة» (loop invariant)؛ وهي نفس بنية برهان صحة خوارزميات التعلّم المتكرّرة (مثل تحديثات mini-batch).

مثال (1.3-3): عدد الحواف في شجرة

المعطيات: شجرة (رسم بياني متصل بلا دورات) ذات n عقدة. المطلوب: إثبات أن عدد الحواف $E(n) = n-1$.

الحل: الخطوة 1 (الأساس $n = 1$): عقدة واحدة، صفر حواف، $1 - 1 = 0$ ✓. الخطوة 2 (الفرض): كل شجرة بـ k عقدة لها $k-1$ حافة. الخطوة 3 (الخطوة): شجرة بـ $k+1$ عقدة تحتوي ورقة (عقدة درجتها 1)؛ بإزالتها نحصل على شجرة بـ k عقدة لها $k-1$ حافة (بالفرض)، وإرجاع الورقة يضيف حافة واحدة: $(k-1)+1 = k = (k+1)-1$ ✓.

النتيجة: $E = n - 1$ لكل شجرة. الربط بالذكاء الاصطناعي: أشجار القرار تحتوي $n-1$ حافة داخلية، والصيغة تحدّد عدد الاختبارات اللازمة لتصنيف عيّنة: عمق الشجرة لا عدد حوافها.

مثال (1.3-4): عدد العقد في شجرة ثنائية كاملة

المعطيات: شجرة ثنائية كاملة ارتفاعها h (الجذر عند المستوى 0). المطلوب: إثبات أن عدد العقد $N(h) = 2^{h+1} - 1$.

الحل: الخطوة 1 (الأساس $h = 0$): عقدة واحدة، $2^1 - 1 = 1$ ✓. الخطوة 2 (الفرض): $N(k) = 2^{k+1} - 1$. الخطوة 3 (الخطوة): شجرة ارتفاع $k+1$ = جذر + شجرتان ارتفاع كلٍّ منهما k: $N(k+1) = 1 + 2N(k) = 1 + 2(2^{k+1} - 1) = 1 + 2^{k+2} - 2 = 2^{k+2} - 1 = 2^{(k+1)+1} - 1$ ✓.

النتيجة: $N = 2^{h+1} - 1$. الربط بالذكاء الاصطناعي: في أشجار القرار، عدد الأوراق $\leq 2^{h+1}$؛ ومنه يُستنتج حدّ «بُعد VC» لأشجار القرار، وهو ما يضبط سعة النموذج.

مثال (1.3-5): تعقيد خوارزمية الدمج (Merge Sort)

المعطيات: $T(1) = 1$، وللدخل بحجم n: $T(n) = 2T(n/2) + n$. المطلوب: إثبات بالاستقراء أن $T(n) = n\log_2 n + n$ عندما يكون n قوةً للعدد 2.

الحل: الخطوة 1 (الأساس $n = 1$): $T(1) = 1 = 0 + 1 = 1 \cdot \log_2 1 + 1$ ✓. الخطوة 2 (الفرض): $T(k) = k\log_2 k + k$. الخطوة 3 (الخطوة، بوضع $n = 2k$): $T(2k) = 2T(k) + 2k = 2(k\log_2 k + k) + 2k = 2k\log_2 k + 4k$. ونحسب الهدف: $2k\log_2(2k) + 2k = 2k(\log_2 k + 1) + 2k = 2k\log_2 k + 4k$ ✓ متطابقان.

النتيجة: $T(n) = \Theta(n\log n)$. الربط بالذكاء الاصطناعي: فرز النتائج في أنظمة الاسترجاع وترتيب أهمية العيّنات (importance sampling) يعملان بهذا التعقيد، وهو أيضاً تعقيد حساب الانتباه الكامل على تسلسل طويل بعد تقنيات التقريب.

مثال (1.3-6): نمو متتالية فيبوناتشي

المعطيات: $F_0 = 0,\ F_1 = 1,\ F_{n+1} = F_n + F_{n-1}$. المطلوب: إثبات $F_n \geq \varphi^{n-2}$ لكل $n \geq 2$ حيث $\varphi = \frac{1+\sqrt{5}}{2} \approx 1.618$.

الحل: الخطوة 1 (الأساس $n = 2$): $F_2 = 1 \geq \varphi^0 = 1$ ✓. الخطوة 2 (الفرض القوي): نفترض الصحة لكل j بحيث $2 \leq j \leq k$. الخطوة 3 (الخطوة): $F_{k+1} = F_k + F_{k-1} \geq \varphi^{k-2} + \varphi^{k-3} = \varphi^{k-3}(\varphi + 1)$. وبما أن $\varphi^2 = \varphi + 1$: $= \varphi^{k-3}\varphi^2 = \varphi^{k-1} = \varphi^{(k+1)-2}$ ✓.

النتيجة: نموٌّ أُسّي بأساس φ. الربط بالذكاء الاصطناعي: الاستقراء **القوي** ضروري هنا لأن الحدّ يعتمد على حدّين سابقين؛ نفس البنية تظهر في حدود تقلّص التدرّج على T خطوة (حيث يعتمد الخطأ على خطأين سابقين).

مثال (1.3-7): متراجحة برنولي

المعطيات: $x > -1$ حقيقي، $n \in \mathbb{N}$. المطلوب: إثبات $(1+x)^n \geq 1 + nx$.

الحل: الخطوة 1 (الأساس $n = 0$): $1 \geq 1$ ✓. الخطوة 2 (الفرض): $(1+x)^k \geq 1 + kx$. الخطوة 3 (الخطوة): $(1+x)^{k+1} = (1+x)^k(1+x) \geq (1+kx)(1+x) = 1 + (k+1)x + kx^2 \geq 1 + (k+1)x$ لأن $kx^2 \geq 0$ ✓.

النتيجة: المتراجحة صحيحة لكل n. الربط بالذكاء الاصطناعي: تُستخدم في إثبات أن تراكم الأخطاء النسبية في ضرب طبقات الشبكة يبقى مضبوطاً، وفي تحليل تضخّم/تلاشي التدرّج $(1+\varepsilon)^L$.

مثال (1.3-8): صحة خوارزمية إقليدس للقاسم المشترك الأكبر

المعطيات: $\gcd(a, b) = \gcd(b,\ a \bmod b)$. المطلوب: إثبات توقّف الخوارزمية وصحّتها بالاستقراء على عدد الخطوات.

الحل: الخطوة 1 (الأساس): إذا كان $b = 0$ فالخوارزمية تُعيد a وهو $\gcd(a,0)$ ✓. الخطوة 2 (الفرض): الخوارزمية صحيحة لكل مدخل يتطلّب k خطوة. الخطوة 3 (الخطوة): لمدخل (a,b) يتطلّب $k+1$ خطوة: الخطوة الأولى تُحوّله إلى $(b, a \bmod b)$ مع $a \bmod b < b$، فينخفض الطرف الثاني انخفاضاً صارماً، فالمدخل الجديد يتطلّب k خطوة (بالفرض صحيح)، وبخاصية $\gcd(a,b) = \gcd(b, a \bmod b)$ تكون النتيجة صحيحة ✓.

النتيجة: الخوارزمية صحيحة وتتوقّف. الربط بالذكاء الاصطناعي: أي خوارزمية تكرارية تحتاج **دالة تنازلية** (variant function) لإثبات التوقّف؛ في التعلّم العميق هذه الدالة هي دالة الخسارة، وشرط «تناقص كافٍ» هو شرط التقارب.

مثال (1.3-9): عدد المجموعات الفرعية

المعطيات: مجموعة S فيها n عنصراً. المطلوب: إثبات أن عدد المجموعات الفرعية $|2^S| = 2^n$.

الحل: الخطوة 1 (الأساس $n = 0$): $S = \emptyset$ لها مجموعة فرعية واحدة، $2^0 = 1$ ✓. الخطوة 2 (الفرض): مجموعة بـ k عنصر لها 2^k مجموعة فرعية. الخطوة 3 (الخطوة): لمجموعة بـ $k+1$ عنصر: نثبّت عنصراً s، المجموعات الفرعية التي لا تحتوي s = 2^k (مجموعات فرعية للباقي)، والتي تحتوي s = 2^k (كل واحدة مضافة إليها s). المجموع $= 2^k + 2^k = 2^{k+1}$ ✓.

النتيجة: 2^n مجموعة فرعية. الربط بالذكاء الاصطناعي: فضاء البحث في اختيار الميزات (feature selection) حجمه 2^n $\Longrightarrow$ مسألة صعبة-NP $\Longrightarrow$ هذا هو مبرّر البحث الجشع والاسترخاء المحدّب (مثل Lasso).

مثال (1.3-10): صحة الانتشار العكسي عبر L طبقة

المعطيات: شبكة $f = f_L \circ f_{L-1} \circ \cdots \circ f_1$؛ الخطأ المعكوس $\delta_\ell = \frac{\partial \mathcal{L}}{\partial z_\ell}$. المطلوب: إثبات صحة علاقة التكرار $\delta_\ell = (W_{\ell+1}^\top \delta_{\ell+1}) \odot \sigma'(z_\ell)$ لكل ℓ.

الحل: الخطوة 1 (الأساس $\ell = L$): $\delta_L = \nabla_{\hat{y}} \mathcal{L} \odot \sigma'(z_L)$ يُحسب مباشرة من دالة الخسارة ✓. الخطوة 2 (الفرض): $\delta_{\ell+1}$ صحيحة. الخطوة 3 (الخطوة): بقاعدة السلسلة على $z_{\ell+1} = W_{\ell+1}\sigma(z_\ell) =: z_{\ell+1}$ $\delta_\ell = \left(\frac{\partial z_{\ell+1}}{\partial z_\ell}\right)^\top \delta_{\ell+1} = \left(W_{\ell+1}\,\mathrm{diag}(\sigma'(z_\ell))\right)^\top \delta_{\ell+1} = (W_{\ell+1}^\top \delta_{\ell+1}) \odot \sigma'(z_\ell)$ ✓. الخطوة 4: بالاستقراء التنازلي من L إلى 1، كل الطبقات صحيحة.

النتيجة: الانتشار العكسي يحسب التدرّج كاملاً بتكلفة O(تكلفة الانتشار الأمامي). الربط بالذكاء الاصطناعي: هذا البرهان هو قلب كل مكتبات التفاضل الآلي (PyTorch/TF)؛ وسيُبسَط في الفصل 36 بصيغة التفاضل الآلي العكسي.

مثال (1.3-11): عدد المعلمات في شبكة التفافية مع تجميع (Pooling)

المعطيات: L طبقات التفافية؛ الطبقة ℓ فيها c_ℓ قناة ونواة $k_\ell \times k_\ell$؛ التجميع لا يضيف معلمات. المطلوب: إثبات أن $W_L = \sum_{\ell=1}^{L} \left(c_{\ell-1} c_\ell k_\ell^2 + c_\ell\right)$.

الحل: الخطوة 1 (الأساس $L = 1$): $W_1 = c_0 c_1 k_1^2 + c_1$ ✓ (نواة لكل زوج قنوات + انحياز لكل قناة). الخطوة 2 (الفرض): الصيغة صحيحة لـ $L = m$. الخطوة 3 (الخطوة): $W_{m+1} = W_m + (c_m c_{m+1} k_{m+1}^2 + c_{m+1})$ (التجميع يضيف صفراً) = الصيغة عند $m+1$ ✓.

النتيجة: تُحسب المعلمات بجمع طبقي؛ التجميع لا يساهم. الربط بالذكاء الاصطناعي: تفسير جوهري لكون الشبكات الالتفافية «أخفّ» من الكاملة الاتصال: النواة مشتركة مكانياً (weight tying).

مثال (1.3.1-12): عدد المسارات في شبكة متبقّية (ResNet)

المعطيات: شبكة بـ L كتلة متبقّية؛ كل كتلة تضيف مساراً (skip connection)؛ ليكن M_L عدد مسارات المعلومات من المدخل إلى المخرج. المعطيات الإضافية: $M_1 = 2$ (مسار مباشر + مسار عبر الكتلة). المطلوب: إثبات $M_L = 2^L$.

الحل: الخطوة 1 (الأساس $L = 1$): $M_1 = 2 = 2^1$ ✓. الخطوة 2 (الفرض): $M_k = 2^k$. الخطوة 3 (الخطوة): عند الكتلة $(k+1)$ كل مسار سابق يتفرّع إلى مسارين (يعبر الكتلة أو يتجاوزها): $M_{k+1} = 2M_k = 2 \cdot 2^k = 2^{k+1}$ ✓.

النتيجة: 2^L مساراً؛ لـ $L = 50$ عدد ضخم. الربط بالذكاء الاصطناعي: هذا هو التفسير «كمجموعة غير صريحة من النماذج» (implicit ensemble) لنجاح ResNet؛ ويُستخدم في تحليل سلاسة سطح الخسارة.

مثال (1.3.1-13): صحة برمجة ديناميكية على سلسلة قرارات ماركوفية

المعطيات: MDP بأفق H؛ قيمة الحالة $V_h(s)$؛ معادلة بيلمان: $V_h(s) = \max_a \big[R(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_{h+1}(s')\big]$ مع $V_H(s) = 0$. المطلوب: إثبات بالاستقراء التنازلي أن الحلّ هو القيمة المثلى.

الحل: الخطوة 1 (الأساس $h = H$): لا مكافآت بعد الأفق، $V_H = 0$ مثلى ✓. الخطوة 2 (الفرض): V_{h+1} هي القيمة المثلى من الخطوة $h+1$ فصاعداً. الخطوة 3 (الخطوة): القيمة المثلى من h = أفضل مكافأة فورية + أفضل استمرار؛ وبمبدأ الأمثلية لبيلمان: $V_h(s) = \max_a[R + \gamma\, \mathbb{E}[V_{h+1}]]$، وبالفرض V_{h+1} مثلية $\Rightarrow$ V_h مثلية ✓. الخطوة 4: بالاستقراء التنازلي إلى $h = 0$ نحصل على السياسة المثلى.

النتيجة: البرمجة الديناميكية العكسية تعطي الحلّ الأمثل. الربط بالذكاء الاصطناعي: هذه البنية الاستقرائية هي أصل الخوارزميات الحديثة في التعلّم التعزيزي، (Q-learning، DQN، PPO) وستُفصَّل في الفصل 44.

مثال (1.3.1-14): تعقيد خوارزمية فرّق-تسد (Master Theorem) بحالة بسيطة

المعطيات: $T(n) = aT(n/b) + cn$ مع $a = b = 2$. المطلوب: إثبات $T(n) = O(n \log n)$ بالاستقراء.

الحل: الخطوة 1 (الأساس $n = 1$): $T(1) = c_0$ ثابت ✓. الخطوة 2 (الفرض): $T(m) \le C\, m \log_2 m$ لكل $m < n$. الخطوة 3 (الخطوة): $T(n) = 2T(n/2) + cn \le 2C\frac{n}{2}\log_2 \frac{n}{2} + cn = Cn(\log_2 n - 1) + cn = Cn\log_2 n - Cn + cn$. الخطوة 4: اختر $C \ge c$ $\Rightarrow$ $-Cn + cn \le 0$ $\Rightarrow$ $T(n) \le Cn \log_2 n$ ✓.

النتيجة: $T(n) \in O(n \log n)$. الربط بالذكاء الاصطناعي: تحليل تكلفة حساب الانتباه متعدد الرؤوس وخوارزميات FFT في الطبقات الالتفافية الطيفية يتبع هذا النمط بالضبط.

مثال (1.3.1-15): نمو حجم الذاكرة في تدريب متعدد الخطوات

المعطيات: تدريب SGD، الذاكرة المطلوبة بعد t خطوة M_t، عند كل خطوة يُخزَّن متوسط متحرّك لتدرّجات $G_t = \beta G_{t-1} + (1-\beta) g_t$ مع $G_0 = 0$. المطلوب: إثبات أن $G_t = (1-\beta)\sum_{i=1}^{t} \beta^{t-i} g_i$ بالاستقراء.

الحل: الخطوة 1 (الأساس $t = 1$): $G_1 = (1-\beta) g_1$ ✓. الخطوة 2 (الفرض): $G_k = (1-\beta)\sum_{i=1}^{k} \beta^{k-i} g_i$. الخطوة 3 (الخطوة): $G_{k+1} = \beta G_k + (1-\beta) g_{k+1} = \beta(1-\beta)\sum_{i=1}^{k} \beta^{k-i} g_i + (1-\beta) g_{k+1} = (1-\beta)\sum_{i=1}^{k+1} \beta^{(k+1)-i} g_i$ ✓.

النتيجة: المتوسط المتحرّك الأُسّي = مرجّح أُسّي لكل التدرّجات السابقة. الربط بالذكاء الاصطناعي: هذا هو جوهر محسّن Adam/RMSProp: الذاكرة ثابتة الحجم ($O(1)$) لكنها تُرمّز تاريخاً كاملاً — مثال كلاسيكي على هيكل بيانات استقرائي.

6.4.1 أخطاء شائعة

الخطأ	الصواب
إثبات الخطوة دون استخدام فرضية الاستقراء	ليست استقراءً؛ مناقشة مباشرة
الأساس عند $n = 1$ والخطوة من k إلى $k+1$ مع خاصية معرّفة من $n = 0$	طابق الأساس مع مجال التعريف
استخدام الاستقراء الضعيف حيث يلزم القوي (مثل فيبوناتشي)	استخدم (13.1) إذا كان الحدّ يعتمد على أكثر من سابق
«دائرة مفرغة»: افتراض النتيجة داخل الخطوة	الفرضية $P(k) \neq$ النتيجة $P(n)$

الفكرة: إذا وضعت n حمامة في m صندوقاً وكان $n > m$، فلا بدّ أن صندوقاً واحداً على الأقل يحوي أكثر من حمامة. بسيطة ... لكنها سلاحٌ قاطع في إثبات الاستحالة والحدود الدنيا.

1.5.1 الصياغة الرسمية

الصيغة الأساسية: إذا وُزّع n عنصراً على m صندوقاً فإن:

$$\exists\, j \in \{1, \dots, m\} : \quad |A_j| \;\geq\; \left\lceil \frac{n}{m} \right\rceil \tag{16.1}$$

الصيغة المتناظرة (صندوقٌ قليل الامتلاء):

$$\exists\, j \in \{1, \dots, m\} : \quad |A_j| \;\leq\; \left\lfloor \frac{n}{m} \right\rfloor \tag{17.1}$$

الصيغة المعمّمة (متوسط):

$$\frac{1}{m}\sum_{j=1}^{m} |A_j| \;=\; \frac{n}{m} \;\Longrightarrow\; \max_j |A_j| \;\geq\; \frac{n}{m} \;\geq\; \min_j |A_j| \tag{18.1}$$

الصيغة اللانهائية: إذا وُزّع عددٌ لانهائي من العناصر على عدد منتهٍ m من الصناديق، فصندوقٌ واحدٌ على الأقل لانهائي.

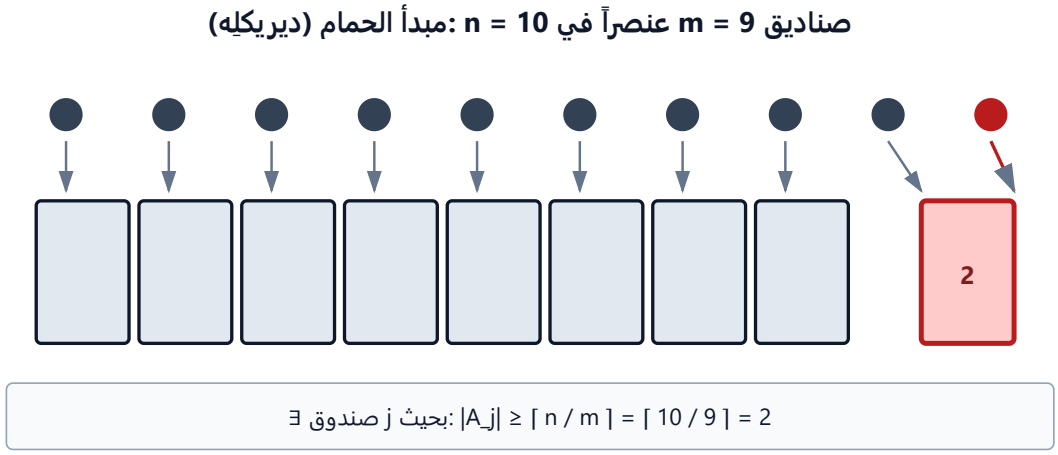
صيغة التصادم (مفتاح الـ hashing):

$$|\mathcal{K}| > |\mathcal{H}| \;\Longrightarrow\; \exists\, x \neq y \in \mathcal{K} :\; h(x) = h(y) \tag{19.1}$$

2.5.1 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
n	عدد العناصر (الحمامات)	حجم المجال	len(items)
m	عدد الصناديق	حجم المدى	num_buckets
A_j	الصندوق j	مجموعة العناصر التي وقعت في الصندوق j	—
$\lvert A_j \rvert$	عدد عناصر الصندوق j	«الامتلاء»	—
$\lceil x \rceil$	دالة السقف	أصغر عدد صحيح $\geq x$	ceil
$\lfloor x \rfloor$	دالة الأرضية	أكبر عدد صحيح $\leq x$	floor
$\exists$	كمّي وجودي	«يوجد»	ضمانة وجودية لا تُحدّد أيّ صندوق
$\max_j$ / $\min_j$	أعظمي/أدنى	عبر كل الصناديق	—
h	دالة تجزئة (Hash)	$h : \mathcal{K} \to \mathcal{H}$	—
$\mathcal{K}$	فضاء المفاتيح	كل المفاتيح الممكنة	قد يكون ضخماً
$\mathcal{H}$	فضاء الصناديق	قيم التجزئة الممكنة	حجمه m
$\Longrightarrow$	الاستلزام المنطقي	—	—

3.5.1 الشكل الهندسي



شكل (1.4): استحالة توزيع 10 عناصر على 9 صناديق دون تكرار

شكل ١.٤: *
مبدأ الحمام

شكل (4.1): عشرة عناصر وتسعة صناديق $\Longrightarrow$ صندوقٌ (المُلوّن) يحوي عنصرين.

4.5.1 البرهان

نُثبت (16.1) بالتناقض، ونُثبت (17.1) مباشرةً:

١. لو كان كل صندوق يحوي على الأكثر $\lceil n/m \rceil - 1$ عنصراً، لكان المجموع $m(\lceil n/m \rceil - 1) \leq$. وبما أن $\lceil n/m \rceil < n/m + 1$، فإن $m(\lceil n/m \rceil - 1) < m \cdot \frac{n}{m} = n$، أي المجموع $<$ — تناقض مع أن المجموع $n =$.

٢. ولو كان كل صندوق يحوي أكثر من $\lfloor n/m \rfloor$ (أي $\geq \lfloor n/m \rfloor + 1 > n/m$) لكان المجموع $> m \cdot \frac{n}{m} = n$ — تناقض أيضاً.

إذن الحدّان (16.1) و (17.1) محقّقان. ■

5.5.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-4.1): تصادم التجزئة في جدول ميزات (Hashing Trick)

المعطيات: مفردات لغوية بحجم 100,001 كلمة تُخزَّن في جدول تجزئة ذي 100,000 خانة. المطلوب: هل يمكن ضمان عدم التصادم؟

الحل: الخطوة 1: $m = 100{,}000 < 100{,}001 = n$. الخطوة 2: بـ (16.1): يوجد صندوق بـ $\geq \lceil 100001/100000 \rceil = 2$ عنصراً. الخطوة 3: إذن كلمتان مختلفتان لهما الخانة ذاتها.

النتيجة: تصادم حتمي (لا احتمالي). الربط بالذكاء الاصطناعي: هذا هو «خدعة التجزئة» (hashing trick) في نماذج اللغة؛ التصادم يقلّل الدقة قليلاً لكنه يوفّر الذاكرة بمرتبة كاملة — مقايضة مقبولة عملياً.

مثال (2-4.1): ضمان تكرار عيد ميلاد

المعطيات: غرفة فيها 367 شخصاً، السنة 366 يوماً (سنة كبيسة). المطلوب: هل يوجد شخصان لهما عيد الميلاد ذاته؟

الحل: الخطوة 1: $n = 367 > m = 366$. الخطوة 2: بـ (16.1): يومٌ واحد على الأقل يقابله $\geq \lceil 367/366 \rceil = 2$ شخص. الخطوة 3: إذن التكرار مضمون بنسبة 100%.

النتيجة: نعم، مضمون. الربط بالذكاء الاصطناعي: «مفارقة عيد الميلاد» الاحتمالية (احتمال > 50% عند 23 شخصاً) تُعمَّم إلى **تحليل احتمال التصادم** في التعلّم المتعادلاتي وفي تقدير حجم الذاكرة العشوائية (Bloom filters).

مثال (3-4.1): استحالة ضغط كل الملفات بدون فقد

المعطيات: كل ملفات الطول b بتّاً عددها 2^b؛ نُريد ضغطها كلها إلى أطوال $< b$. المطلوب: هل توجد خوارزمية ضغط تفقدية-صفرية تفعل ذلك؟

الحل: الخطوة 1: عدد الملفات الممكنة بطول أصغر من b هو $\sum_{i=0}^{b-1} 2^i = 2^b - 1$. الخطوة 2: $n = 2^b$ ملفاً في $m = 2^b - 1$ صندوقاً $\Rightarrow n > m$. الخطوة 3: بـ (16.1): ملفّان مختلفان لهما نفس الناتج $\Rightarrow$ فكّ الضغط لا يمكن أن يكون وحيداً.

النتيجة: **مستحيل رياضياً**؛ كل خوارزمية ضغط فعّالة تفقد البيانات على بعض المدخلات. الربط بالذكاء الاصطناعي: هذا هو البرهان المعلوماتي على أن «تعقيد كولموجوروف» غير قابل للحساب عموماً، وهو أساس مبدأ MDL في اختيار النماذج (الفصل 28).

مثال (4-4.1): كفاية عدد الخلايا العصبية لتغطية فضاء المدخلات

المعطيات: مصنّف ذو N خلية في الطبقة المخفية الأولى، ومدخلات ثنائية من $\{0,1\}^d$. المطلوب: إذا كان $N < 2^d$، هل يمكن أن تُفعّل كل خلية نمطاً فريداً لكل مدخل؟

الحل: الخطوة 1: عدد المدخلات الممكنة $n = 2^d$، عدد الأنماط المتاحة $m = 2^N$. الخطوة 2: بما أن $N < 2^d$ فـ $m = 2^N$... نحتاج مقارنة عدد الخلايا بأنماطها: كل خلية نمط تفعيل ثنائي $\Longrightarrow$ عدد الأنماط المميّزة $= 2^N$؛ ولتمييز 2^d مدخلاً نحتاج $2^N \geq 2^d$ أي $N \geq d$. الخطوة 3: بالمبدأ: إن كان $2^N < 2^d$ فمدخلان مختلفان لهما نمط التفعيل ذاته $\Longrightarrow$ لا يمكن التفريق بينهما.

النتيجة: شرط ضروري: $N \geq d$ خلية على الأقل لتمييز كل المدخلات الثنائية. الربط بالذكاء الاصطناعي: هذا أضعف أشكال «حدود السعة» (capacity bounds) التي ستظهر بصيغة قوية في نظرية التقريب الشامل وبُعد VC (الفصلان 31 و 35).

مثال (1.4-5): عدد العينات اللازمة لـ «سحق» صنف دوال

المعطيات: صنفٌ من الدوال يضم $|\mathcal{F}| = 2^{50}$ دالة؛ نريد أن نفرّق بينها ببيانات. المطلوب: كم عيّنة على الأقل نحتاج؟

الحل: الخطوة 1: كل عيّنة تُعطي إجابة ثنائية $\Longrightarrow$ n عيّنة تنتج 2^n نمط وسوم ممكناً. الخطوة 2: للتفريق بين 2^{50} دالة نحتاج $2^n \geq 2^{50}$ أي $n \geq 50$. الخطوة 3: إن كان $n = 49$ فبـ (1.6): توجد دالتان مختلفتان لهما نمط الوسوم ذاته على البيانات $\Longrightarrow$ لا نميزهما.

النتيجة: 50 عيّنة على الأقل. الربط بالذكاء الاصطناعي: هذه البذرة الأولى لمفهوم **بُعد VC**: عدد النقاط التي يمكن «سحقها» (shatter) يحدّد سعة الصنف، ومنه حدود التعميم.

مثال (1.4-6): جدولة مهام تدريب على خوادم

المعطيات: 10 مهام تدريب على 8 خوادم متطابقة. المطلوب: أثبت أن خادماً سيستقبل مهمتين على الأقل، وما أطول وقت انتظار مضمون إذا كانت كل مهمة تستغرق ساعة؟*

الحل: الخطوة 1: $n = 10$، $m = 8 \Longrightarrow \lceil 10/8 \rceil = 2$. الخطوة 2: خادمٌ ما يستقبل ≥ 2 مهمتين. الخطوة 3: زمنه $\geq$ ساعتين $\Longrightarrow$ أطول وقت إنجاز مضمون $\geq$ ساعتين (lower bound).

النتيجة: مهلة الضمان الأدنى: ساعتان. الربط بالذكاء الاصطناعي: حدود «نظرية الجدولة» (scheduling lower bounds) تحدّد زمن التدريب الموزّع ولا يمكن لأي خوارزمية ذكية تجاوزها.

مثال (1.4-7): لعنة الأبعاد — تغطية شبكة

المعطيات: نريد شبكةً على $[0,1]^d$ بخطوة 0.1 في كل بُعد؛ عدد خلايا الشبكة 10^d. عدد العيّنات المتاحة 1,000,000. المطلوب: ما أكبر بُعد d يمكن تغطيته (خلية واحدة لكل عيّنة على الأكثر)؟

الحل: الخطوة 1: التغطية الكاملة تتطلّب $n \geq m$ أي $10^d \geq 10^6$. الخطوة 2: $\Longrightarrow d \leq 6$. الخطوة 3: عند $d = 7$: $10^7 > 10^6$ $\Longrightarrow$ بـ (1.6) توجد خلية فارغة... بل العكس: خلايا أكثر من النقاط $\Longrightarrow$ **معظم الخلايا فارغة.**

النتيجة: التغطية ممكنة حتى 6 أبعاد فقط. الربط بالذكاء الاصطناعي: هذا هو التفسير الكمّي لـ «لعنة الأبعاد»: حجم

الفضاء ينمو أُسّياً مع d، فتصبح البيانات متناثرة، ومنه الحاجة إلى تقليل الأبعاد والتعلّم بتمثيلات (representation learning).

مثال (١.٤-8): كشف التكرار بـ MinHash

المعطيات: 5,000 مستند، عدد دلاء (buckets) التوقيع 1,000. المطلوب: هل يُتوقّع تصادم غير مرغوب (مستندان غير متشابهين في دلو واحد)؟

الحل: الخطوة 1: بتوزيع متوازن: متوسط الامتلاء $5000/1000 = 5$ مستند/دلو. الخطوة 2: بـ (١.١٦): يوجد دلو بـ ≥ 5 مستندات. الخطوة 3: كل دلو يحتوي أكثر من مستند $\Longrightarrow$ فحص أزواج داخل الدلو $\sum_j \binom{|A_j|}{2} =$.

النتيجة: التصادم حتمي؛ عدد الأزواج المفحوصة $1000 \cdot \binom{5}{2} = 10{,}000 \approx$ زوجاً. الربط بالذكاء الاصطناعي: في إزالة تكرار بيانات التدريب (deduplication) تُحدّد هذه الحسابات ميزانية الحوسبة قبل تدريب نموذج لغة كبير.

مثال (١.٤-9): تصادم في البحث بالجوار التقريبي (LSH)

المعطيات: 200,000 متجه عنصر في نظام توصية، جدول LSH ذو 50,000 دلو. المطلوب: متوسط عدد المرشحين لكل استعلام.

الحل: الخطوة 1: متوسط الامتلاء $200{,}000/50{,}000 = 4 =$. الخطوة 2: بـ (١.١٦): دلوٌ بـ ≥ 4 عناصر. الخطوة 3: بـ (١.١٧): دلوٌ بـ ≤ 4 عناصر.

النتيجة: ≈ 4 مرشّحين/استعلام بدل 200,000 (تسريع ×50,000). الربط بالذكاء الاصطناعي: LSH هو العمود الفقري للاسترجاع الكثيف السريع (FAISS) في أنظمة RAG الحديثة؛ المبدأ يضمن أن الاستعلام يفحص جزءاً ضئيلاً من الفهرس.

مثال (١.٤-10): درجات الطلاب

المعطيات: 101 طالب، الدرجات أعداد صحيحة من 0 إلى 100. المطلوب: أثبت أن طالبين لهما الدرجة ذاتها.

الحل: الخطوة 1: $n = 101$ طالب، $m = 101$ درجة ممكنة $(0 \ldots 100)$. الخطوة 2: هنا $n = m$ فلا يكفي المبدأ الأساسي؛ نفحص: إن كانت الدرجات كلها مختلفة فهي بالضبط $\{0, 1, \ldots, 100\}$. الخطوة 3: إن أضفنا طالباً واحداً $(n = 102)$ فـ $\lceil 102/101 \rceil = 2 \Longrightarrow$ تكرار حتمي. الخطوة 4: مع 101 طالب: التكرار **غير** مضمون لكنه ممكن.

النتيجة: الضمان يتطلّب 102 طالباً. الربط بالذكاء الاصطناعي: **درس منهجي:** تحقّق دائماً من صرامة المتراجحة ($<$ لا $\leq$ قبل تطبيق المبدأ؛ كثير من «البراهين» الخاطئة تنشأ من هذه النقطة وحدها.

مثال (١.٤-11): توزيع حزم الشبكة على صفوف المعالجة

المعطيات: 12,000 حزمة بيانات تُوجَّه إلى 256 صفاً (queue) في مُوجّه ذكي. المطلوب: كم حزمة في أكثر صفّ امتلاءً على الأقل؟

الحل: الخطوة 1: $\lceil 12000/256 \rceil = \lceil 46.875 \rceil = 47$. الخطوة 2: بـ (16.1): صفٌّ ما يحوي ≥ 47 حزمة. الخطوة 3: إن كانت السعة القصوى للصفّ 40 $\Longrightarrow$ فقدان حزم حتمي.

النتيجة: يلزم ≥ 47 سعة أو موازنة أفضل. الربط بالذكاء الاصطناعي: في أنظمة الاستدلال الموزّعة تحدّد هذه الحدود حجم «الوسادة» (buffer) لتجنّب فقدان الطلبات في أوقات الذروة.

مثال (12-4.1): تصادم التكميم (Quantization)

المعطيات: تكميم أوزان شبكة من 100,000 قيمة عشرية مختلفة إلى 256 مستوى (8-بت). المطلوب: كم قيمة تشترك في المستوى ذاته على الأقل؟

الحل: الخطوة 1: $n = 100{,}000$، $m = 256 \Longrightarrow \lceil 100000/256 \rceil = \lceil 390.625 \rceil = 391$. الخطوة 2: مستوىً ما يجمع ≥ 391 قيمةً مختلفةً تماماً.

النتيجة: خطأ التكميم لا يمكن أن يكون صفراً، ≥ 391 قيمة تندمج. الربط بالذكاء الاصطناعي: هذا يفسّر فقدان الدقة في quantization int8 للنماذج، ويبرّر تقنيات المعايرة (calibration) والمقاييس لكل قناة بدل مقياس عالمي.

مثال (13-4.1): توزيع النقاط في عناقيد k-means

المعطيات: 10,000 نقطة بيانات موزّعة على 20 عنقوداً. المطلوب: أثبت وجود عنقود بـ ≥ 500 نقطة، وآخر بـ ≤ 500 نقطة.

الحل: الخطوة 1: المتوسط $= 10000/20 = 500$. الخطوة 2: بـ (18.1): $\min_j |A_j| \leq 500 \leq \max_j |A_j|$. الخطوة 3: بـ (16.1): $\lceil 500 \rceil = 500 \Longrightarrow$ عنقود بـ ≥ 500.

النتيجة: لا يمكن أن تكون كل العناقيد متساوية تماماً إلا إذا كانت كلها 500 بالضبط. الربط بالذكاء الاصطناعي: عدم التوازن العنقودي يسبّب «انهيار العناقيد» في التعلّم الذاتي الإشراف (مثل SWAV و DINO)؛ ومنه تُصمَّم خسارة الإنتروبيا الموحّدة (unfiormity loss).

مثال (14-4.1): تصادم معرّفات الجلسات (Session IDs)

المعطيات: نظام يولّد معرّفات جلسة من 32 بتّاً، يُتوقّع 100,000 جلسة نشطة متزامنة. المطلوب: هل التصادم مضمون؟

الحل: الخطوة 1: عدد القيم الممكنة $m = 2^{32} = 4{,}294{,}967{,}296$. الخطوة 2: $n = 10^5 \ll m \Longrightarrow$ المبدأ لا يضمن تصادماً. الخطوة 3: لكن بصيغة عيد الميلاد الاحتمالية: $\mathbb{P}(\text{تصادم}) \approx 1 - e^{-n^2/(2m)} = 1 - e^{-10^{10}/(8.6\times10^9)} \approx 1 - e^{-1.16} \approx 0.69$.

النتيجة: التصادم غير مضمون حتمياً لكن احتماله $\approx 69\%$. الربط بالذكاء الاصطناعي: **مهم:** مبدأ الحمام يعطي **ضماناً حتمياً** فقط، وعند $n < m$ ننتقل إلى أدوات احتمالية (طريقة الاحتمال — Probabilistic Method، الفصل 17).

مثال (15-4.1): عناوين IP والأجهزة خلف NAT

المعطيات: موجّه NAT يملك 1 عنوان IP عام و 16,384 منفذاً متاحاً (2^{14}). المطلوب: كم جهازاً يمكن خدمته بضمان (اتصال لكل جهاز)؟

الحل: الخطوة 1: «الصناديق» = المنافذ، عددها $m = 16{,}384$. الخطوة 2: لضمان منفذ فريد لكل جهاز: $n \le m$. الخطوة 3: إن كان $n = 20{,}000$ جهازاً فـ $\lceil 20000/16384 \rceil = 2 \implies$ منفذٌ مشترك $\implies$ تصادم في ترجمة العناوين.

النتيجة: الحدّ المضمون 16,384 جهازاً متزامناً. الربط بالذكاء الاصطناعي: نفس البنية تظهر في «ميزانية المنافذ/السياقات» لخوادم الاستدلال التي تخدم آلاف النماذج؛ تجاوزها يعني تأخيراً أو رفضاً للطلبات.

6.5.1 أخطاء شائعة

الخطأ	الصواب
تطبيق المبدأ عند $n = m$	الشرط **الصارم** هو $n > m$
المبدأ «يقول أيّ صندوق»	المبدأ وجودي؛ لا يحدّد الصندوق
اعتباره أداة احتمالية	هو ضمان حتمي؛ الاحتمال حالة أخرى
نسيان أن الصناديق قد تكون فارغة	صيغة (17.1) تتعامل معها

الفكرة: الاستدلال الآلي ليس «تفكيراً» بل **تطبيقٌ متكرّر لقواعد محفوظة الصحة.** وقاعدة الاستيعاب (Resolution) وحدها تكفي — مع التناقض — لإثبات أي نتيجة في المنطق القضيوي. عليها بُنيت محرّكات SAT الحديثة.

1.6.1 الصياغة الرسمية

قواعد الاستدلال الأساسية (تُكتب كأُطر استدلال: ما فوق الخط مقدّمات، ما تحته نتيجة):

$$\textbf{MP:}\quad \frac{P,\qquad P \to Q}{Q} \tag{20.1}$$

$$\textbf{MT:}\quad \frac{\neg Q,\qquad P \to Q}{\neg P} \tag{21.1}$$

$$\textbf{HS:}\quad \frac{P \to Q,\qquad Q \to R}{P \to R} \tag{22.1}$$

$$\textbf{DS:}\quad \frac{P \lor Q,\qquad \neg P}{Q} \tag{23.1}$$

$$\textbf{Conj:}\quad \frac{P,\qquad Q}{P \land Q} \qquad\qquad \textbf{Simp:}\quad \frac{P \land Q}{P} \tag{24.1}$$

قاعدة الاستيعاب (Resolution) — قلب محرّكات SAT:

$$\frac{P \vee Q, \qquad \neg P \vee R}{Q \vee R} \tag{25.1}$$

الاستيعاب الوحدوي (Unit Resolution) — حالة خاصة بكثرة الاستخدام العملي:

$$\frac{P \vee Q, \qquad \neg P}{Q} \tag{26.1}$$

الاستيعاب بالتناقض (Refutation Completeness):

$$\Gamma \cup \{\neg \varphi\} \vdash_{\text{Res}} \square \iff \Gamma \models \varphi \tag{27.1}$$

نظرية الصحة والكمال (Soundness & Completeness):

$$\Gamma \vdash \varphi \iff \Gamma \models \varphi \tag{28.1}$$

2.6.1 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
$\frac{A}{B}$	إطار استدلال	من المقدّمات A نستنتج B	« rule inference »
$P \to Q$	اللزوم المادي	كاذب فقط إذا $P = 1$ و $Q = 0$	ليس سببية
$\vdash$	الاشتقاق التركيبي	يوجد برهان بالقواعد	« provability »
$\models$	اللزوم الدلالي	كل نموذج يُحقّق المقدّمات يُحقّق النتيجة	« entailment »
$\square$	الفقرة الفارغة	التناقض (empty clause)	تعني «غير قابل للإرضاء»
Γ	قاعدة المعرفة	مجموعة الصيغ/الحقائق	base knowledge
φ	الهدف	الصيغة المراد إثباتها	goal / query
$\vdash_{\text{Res}}$	اشتقاق بالاستيعاب	تقييد القواعد على (25.1)	—
$\neg\varphi$	نفي الهدف	يُضاف للتناقض في (27.1)	« refutation as negation »
clause في الـ $\vee$	فصل الحروف	الـ clause = فصل (OR) رموز	صيغة CNF
Literal	حرف	رمز أو نفيه (P أو $\neg P$)	وحدة بناء الـ clause

3.6.1 الشكل الهندسي

شكل (5.1): أعلى: وضع القضية (MP). أسفل: الاستيعاب يدمج فصلين يتضادّان في P فيُلغيانه.

4.6.1 البرهان

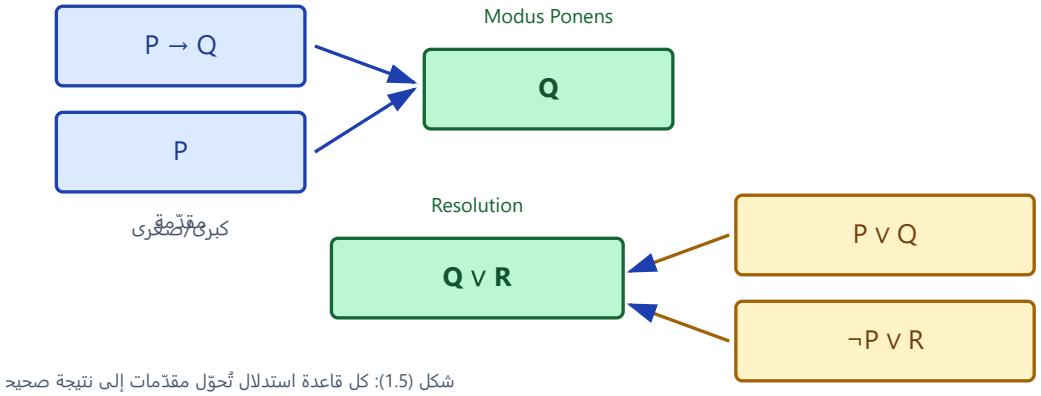
صحة (20.1) Ponens Modus بجدول الصدق:

P	Q	$P \to Q$	$P \wedge (P \to Q)$	النتيجة Q
0	0	1	0	—
0	1	1	0	—
1	0	0	0	—
1	**1**	1	**1**	✓ **1**

في الصف الوحيد الذي تصدق فيه المقدّمات معاً ($P = 1, P \to Q = 1$) تكون $Q = 1$ $\Longrightarrow$ القاعدة صحيحة.

صحة (25.1) الاستيعاب: نُثبت أن $(P \vee Q) \wedge (\neg P \vee R) \models (Q \vee R)$. نفترض نموذجاً يُحقّق المقدّمتين ولا يُحقّق النتيجة، أي $Q = 0$ و $R = 0$:

(Resolution) وقاعدة الاستيعاب (MP) قواعد الاستدلال: وضع القضية



شكل (1.5): كل قاعدة استدلال تُحوّل مقدّمات إلى نتيجة صحيح

شكل ٥.١: *
قواعد الاستدلال

$$(P \vee \underbrace{Q}_{0}) \wedge (\neg P \vee \underbrace{R}_{0}) \;=\; P \wedge \neg P \;=\; \bot$$

تناقض $\Rightarrow$ لا يوجد نموذج مضاد $\Rightarrow$ القاعدة صحيحة. ■

ملاحظة على الكمال:

(28.1) جهة «الصحة» ($\Rightarrow$) بسيطة بالاستقراء على طول البرهان؛ جهة «الكمال» ($\Leftarrow$) أعمق (نظرية كمال غودل للمنطق القضيوي 1929، وصيغة الاستيعاب عند Robinson 1965) وتحتاج بناء نموذج من مجموعة متسقة قصوى — تُناقَش في فهرس المراجع.

5.6.1 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-5.1): نظام خبير طبي — التهاب السحايا

المعطيات: قاعدة المعرفة Γ:

١. $Fever \wedge NeckStiff \rightarrow Meningitis$

٢. $Meningitis \rightarrow Urgent$، حقائق: $Fever = 1$، $NeckStiff = 1$. المطلوب: هل الحالة عاجلة؟

الحل: الخطوة 1: من الحقائق و (Conj-24.1): $Fever \wedge NeckStiff = 1$. الخطوة 2: بـ MP (20.1) مع القاعدة 1: $Meningitis = 1$. الخطوة 3: بـ MP مع القاعدة 2 و $Meningitis = 1$: $Urgent = 1$. الخطوة 4: سلسلة الاشتقاق: $\Gamma \vdash Urgent$.
النتيجة: نعم، عاجلة. الربط بالذكاء الاصطناعي: هذه هي بنية النظم الخبيرة الكلاسيكية ؛(MYCIN) وفي الأنظمة الحديثة تُترجم القواعد إلى قيود ناعمة في نموذج عصبي-رمزي.

مثال (1.5-2): روبوت خدمة في مستشفى

المعطيات: 1. $BatteryLow \rightarrow ReturnToDock$؛ 2. $ReturnToDock \rightarrow \neg Deliver$؛ 3. $TaskAssigned \rightarrow Deliver$. الحقائق: $BatteryLow = 1$، $TaskAssigned = 1$. المطلوب: هل هناك تناقض في الأهداف؟

الحل: الخطوة 1: بـ MP مع 1: $ReturnToDock = 1$. الخطوة 2: بـ MP مع 2: $\neg Deliver = 1$ أي $Deliver = 0$. الخطوة 3: بـ MP مع 3 و $TaskAssigned = 1$: $Deliver = 1$. الخطوة 4: $Deliver \wedge \neg Deliver = \bot$ $\Longrightarrow$ تناقض.

النتيجة: نعم — يلزم منطق إعادة التخطيط أو استرخاء القيود. الربط بالذكاء الاصطناعي: كشف التناقض هو وظيفة مُخطِّط المهام؛ الأنظمة الحديثة تستخدم SAT/SMT لحلّه قبل التنفيذ (بدل الفشل أثناء الحركة).

مثال (1.5-3): تشخيص عطل في خط إنتاج

المعطيات: 1. $TempHigh \vee PressHigh$؛ 2. $PressHigh \rightarrow ValveFault$؛ 3. $\neg ValveFault$. المطلوب: استنتج العطل.

الحل: الخطوة 1: من 2 و 3 بـ MT (1.21): $\neg PressHigh$. الخطوة 2: من 1 و $\neg PressHigh$ بـ DS (1.23): $TempHigh$.

النتيجة: العطل ارتفاع الحرارة. الربط بالذكاء الاصطناعي: هذا «الاستدلال بالاستبعاد» هو نفسه ما تفعله أشجار القرار عند تتبّع مسار تصنيف، لكن بصيغة رمزية قابلة للتفسير والمراجعة.

مثال (1.5-4): قواعد أعمال في نظام توصية

المعطيات: 1. $NewUser \rightarrow ShowPopular$؛ 2. $ShowPopular \rightarrow \neg ShowNiche$؛ 3. $Premium \wedge \neg NewUser \rightarrow ShowNiche$. مستخدم: $Premium = 1$، $NewUser = 1$. المطلوب: ماذا يُعرض؟

الحل: الخطوة 1: بـ MP مع 1 و $NewUser = 1$: $ShowPopular = 1$. الخطوة 2: بـ MP مع 2: $\neg ShowNiche$. الخطوة 3: شرط القاعدة 3 يحتاج $\neg NewUser$ وهو 0 $\Longrightarrow$ لا تُطبَّق.

النتيجة: يُعرض «الشائع» فقط. الربط بالذكاء الاصطناعي: طبقات القواعد فوق نموذج التوصية (business rules layer) ضرورية للامتثال، ويجب فحص تناقضها آلياً قبل النشر.

مثال (1.5-5): التحقق من صحة برنامج (منطق هور)

المعطيات: ثلاثية هور $\{P\}$ code $\{Q\}$، لدينا:

١. $\{x > 0\}$ x+1 =: y $\{y > 1\}$؛ 2. $\{y > 1\}$ y*2 =: z $\{z > 2\}$. المطلوب: إثبات $\{x > 2\}$ z:=y*2 y:=x+1; $\{z > 0\}$.

الحل: الخطوة 1: بـ HS (22.1) نربط النتيجتين: من $\{x > 0\}$ نصل إلى $\{y > 1\}$ ثم إلى $\{z > 2\}$. الخطوة 2: قاعدة التركيب (Composition) في منطق هور هي بالضبط HS. الخطوة 3: إذن الثلاثية المركّبة صحيحة.

النتيجة: البرهان مقبول. الربط بالذكاء الاصطناعي: أدوات التحقق من عتاد/برمجيات الذكاء الاصطناعي (مثل التحقق من صحة مُجمّعات النماذج) تعتمد هذه السلاسل الاستدلالية.

مثال (1.5-6): استدلال في Prolog

المعطيات: قاعدة المعرفة: `` parent(ahmad, sara). parent(sara, omar). grandparent(X,Z) :- parent(X,Y), parent(Y,Z)`` المطلوب:* هل grandparent(ahmad, omar)؟

الحل: الخطوة 1: القاعدة بلغة الاستيعاب: $\neg parent(X,Y) \vee \neg parent(Y,Z) \vee grandparent(X,Z)$.

الخطوة 2: الوحدة $\neg grandparent(ahmad, omar)$ تُضاف للتناقض (27.1). الخطوة 3: بالاستيعاب مع الحقيقة $\neg parent(sara, Z) \vee grandparent(ahmad, Z) \Longrightarrow parent(ahmad, sara)$. الخطوة 4: بالاستيعاب مع $grandparent(ahmad, omar) \Longrightarrow parent(sara, omar)$ تعارض مع الوحدة المنفية $\Longrightarrow \square$.

النتيجة: نعم، أحمد جدّ عمر. الربط بالذكاء الاصطناعي: محرّك Prolog هو مقوّض استيعابي (SLD-resolution)؛ وفهمه شرط لفهم محرّكات الاستدلال الحديثة على الرسوم المعرفية.

مثال (1.5-7): ربط تنبيهات أمنية (SIEM) (Correlation)

المعطيات: 1. $FailedLogin \wedge Repeated \rightarrow BruteForce$، 2. $BruteForce \vee Exfiltration \rightarrow HighSeverity$، 3. $\neg HighSeverity$ (السياسة تمنع التصعيد الآن). المطلوب: ماذا يُستنتج؟

الحل: الخطوة 1: بـ MT (21.1) على 2 مع $\neg HighSeverity$: $\neg(BruteForce \vee Exfiltration)$.

الخطوة 2: بدي مورغان (2.1): $\neg BruteForce \wedge \neg Exfiltration$. الخطوة 3: بـ Simp: $\neg BruteForce$.

الخطوة 4: بـ MT على 1: $\neg(FailedLogin \wedge Repeated)$ $\Longrightarrow$ بدي مورغان: $\neg FailedLogin \vee \neg Repeated$.

النتيجة: ليس هناك هجوم قوي؛ والتنبيهات فردية عابرة. الربط بالذكاء الاصطناعي: «الاستدلال العكسي» (backward chaining) من السياسة إلى التنبيهات يقلّل الإيجابيات الكاذبة بنسبة كبيرة مقابل الاستدلال الأمامي الأعمى.

مثال (1.5-8): استدلال على رسم معرفي (Knowledge Graph)

المعطيات: 1. $LocatedIn(X,Y) \wedge CapitalOf(Y,Z) \rightarrow LocatedIn(X,Z)$ (انتقالية)؛ الحقائق: $LocatedIn(Cairo_Tower,\ Egypt)$، $CapitalOf(Egypt,\ Cairo)$... (لنصحّح: $Egypt \rightarrow Cairo$ علاقة hasCapital). المطلوب: استنتاج جديد قابل للاشتقاق.

الحل: الخطوة 1: نُطبّق MP على القاعدة مع الحقائق: $\wedge\ LocatedIn(Cairo_Tower,\ Egypt)$ $hasCapital(Egypt, Cairo)$. الخطوة 2: إذا كانت القاعدة: $LocatedIn(X,Y) \wedge hasCapital(Y,Z) \rightarrow NearCapital(Cairo_Tower,\ Cairo) \Longrightarrow NearCapital(X,Z)$. الخطوة 3: تُضاف الحقيقة الجديدة للرسم (materialization).

النتيجة: حقيقة جديدة مُشتقّة. الربط بالذكاء الاصطناعي: «إتمام الرسم المعرفي» (KG completion) يمكن أن يكون رمزياً (بالقواعد) أو تعلّمياً (تضمينات مثل TransE)؛ والنُهج الهجينة هي الأفضل حالياً.

مثال (1.5-9): نظام مرور ذكي

المعطيات: 1. $ExtendGreen \rightarrow \neg Congestion \wedge \neg Emergency$؛ 2. $Emergency \rightarrow Accident$؛ 3. $\neg ExtendGreen$. الحقائق: $Congestion = 1$، $Accident = 1$. المطلوب: ماذا يفعل النظام؟

الحل: الخطوة 1: بـ MP مع 3: $Emergency = 1$. الخطوة 2: بـ MP مع 2: $\neg ExtendGreen$. الخطوة 3: القاعدة 1 غير مُطبّقة (شرطها $\neg Emergency$ كاذب).

النتيجة: لا تمديد للأخضر؛ أولوية للطوارئ. الربط بالذكاء الاصطناعي: القواعد ذات الأولويات تُدار بـ «منطق التفضيل» (preference logic)؛ وعند تعارضها يلزم تحكّم (arbitration) صريح لا MP بسيط.

مثال (1.5-10): موافقة ائتمانية بنكية

المعطيات: 1. $ScoreHigh \rightarrow Approve$؛ 2. $DebtHigh \rightarrow \neg Approve$؛ 3. $ScoreHigh \vee DebtHigh$ (حصر). مقدم: $ScoreHigh = 1$. المطلوب: القرار وهل القواعد متسقة؟

الحل: الخطوة 1: بـ MP مع 1: $Approve = 1$. الخطوة 2: من 3 و $ScoreHigh$ بـ DS نستنتج... بل: $ScoreHigh \vee DebtHigh$ صادق أصلاً، لا نستنتج $\neg DebtHigh$ إلّا بالحصر. الخطوة 3: **فحص التساق:** النموذج $ScoreHigh = 1,\ DebtHigh = 1$ يُحقّق 3 ويُنتج من 1 $Approve$ ومن 2 $\neg Approve$ $\Longrightarrow$ **غير متسقة.**

النتيجة: قاعدة المعرفة متناقضة $\Longrightarrow$ يلزم قاعدة أولوية (مثلاً: $DebtHigh$ يعلو). الربط بالذكاء الاصطناعي: «اكتشاف التناقض في قواعد الأعمال» خطوة إلزامية قبل تشغيل أي نظام قرار آلي؛ ويُنفَّذ باستدعاء SAT solver.

مثال (1.5-11): استدلال سببي (Causal Inference)

المعطيات: 1. $Smoking \rightarrow Tar$؛ 2. $Tar \rightarrow Cancer$؛ 3. ملاحظة: $\neg Cancer$ لدى مريض. المطلوب: ماذا نستنتج عن التدخين؟ ولماذا هذا ليس دليلاً سببياً كافياً؟

الحل: الخطوة 1: بـ HS (1.22) من 1 و 2: $Cancer \rightarrow Smoking$. الخطوة 2: بـ MT (1.21) مع $\neg Cancer$: $\neg Smoking$. الخطوة 3: **تحذير:** هذا الاستنتاج صحيح **دلالياً** فقط إذا كانت القواعد صادقة حتمياً؛ في الواقع العلاقات احتمالية فتُستبدل بـ $\mathbb{P}(Cancer \mid do(Smoking))$ (حساب تفاضلي سببي).

النتيجة: منطقياً $\neg Smoking$؛ سببياً: استنتاج ضعيف. الربط بالذكاء الاصطناعي: **درس جوهري:** $P \rightarrow Q$ لزومٌ مادي لا سببية؛ الارتباط $\neq$ السببية، والاستدلال السببي يحتاج تدخّلات $do(\cdot)$ لا ملاحظات.

مثال (1.5-12): تحويل قاعدة إلى قيد في خسارة عصبية-رمزية

المعطيات: قاعدة: $HasWings \wedge \neg CanFly \rightarrow Penguin$. نريد فرضها في تدريب شبكة. المطلوب: صياغة القيد ودالة الخسارة.

الحل: الخطوة 1: نحوّل القاعدة إلى CNF: $\neg HasWings \vee CanFly \vee Penguin$. الخطوة 2: درجة الإرضاء الضبابية بمنطق لوكاسيفيتش: $\mu = \min\{1,\ (1-\mu_W) + \mu_F + \mu_P\}$. الخطوة 3: الخسارة $\mathcal{L}_{rule} = \lambda\,(1-\mu)$؛ نجمعها مع خسارة التصنيف. الخطوة 4: التدرّج يجعل الشبكة تُرضي القاعدة تدريجياً.

النتيجة: قيدٌ قابل للاشتقاق. الربط بالذكاء الاصطناعي: هذا هو جوهر الذكاء العصبي-الرمزي (Neuro-Symbolic AI): المنطق يصبح منتظِماً (regularizer) لا مرشّحاً بعدياً.

مثال (1.5-13): تحليل السبب الجذري في خدمة سحابية

المعطيات: 1. $DiskFull \vee MemLeak \rightarrow Slow$؛ 2. $Slow \rightarrow Timeouts$؛ 3. $Timeouts \rightarrow \neg SLO$؛ 4. $\neg DiskFull$ (مؤكَّد بالقياس). الحقائق: $\neg SLO = 1$ (انتهاك اتفاقية المستوى). المطلوب: السبب الجذري.

الحل: الخطوة 1: لا يمكن عكس MT 3 يعطي $\neg SLO \Rightarrow$ لا شيء؛ MT يعمل من نفي التالي: $\neg Timeouts$... غير متاح). نستخدم الاستيعاب: الخطوة 2: الصيغ كـ clauses: $(\neg DiskFull \vee Slow)$... نعيد صياغة 1: $DiskFull \vee MemLeak \vee Slow$ لا، بل 1 هي $(DiskFull \vee MemLeak) \rightarrow Slow \equiv (\neg DiskFull \vee Slow) \wedge (\neg MemLeak \vee Slow)$. الخطوة 3: من $\neg DiskFull$ و $(\neg DiskFull \vee Slow)$ لا نستنتج $Slow$ (الوحدة موجبة). نحتاج ملاحظة $Slow$ لاستنتاج $MemLeak$ من $(\neg MemLeak \vee Slow)$؟ بـ MT على $(MemLeak \rightarrow Slow) \equiv (\neg MemLeak \vee Slow)$ نحتاج $\neg Slow$. الخطوة 4: بالتحليل: القرائن المتاحة لا تكفي لتحديد السبب $\Longrightarrow$ **الاستنتاج غير حاسم.**

النتيجة: المعطيات غير كافية، يلزم قياس إضافي. الربط بالذكاء الاصطناعي: **درس منهجي مهم:** غياب الاستنتاج مشكلة بحدّ ذاته، تُعالَج بـ «المنطق غير المتأكد» (abduction) حيث نبحث عن أصغر تفسير (minimal explanation) — وهو ما تفعله أنظمة AIOps الحديثة.

مثال (1.5-14): امتثال تنظيمي (Regulatory Compliance)

المعطيات: 1. $EUResident \wedge PersonalData \rightarrow GDPRApplies$؛ 2. $GDPRApplies \rightarrow ConsentRequired$؛ 3. $ConsentRequired \wedge \neg ConsentLogged \rightarrow Violation$. حالة: $EUResident = 1$، $PersonalData = 1$، $ConsentLogged = 0$. المطلوب: هل هناك انتهاك؟

الحل: الخطوة 1: بـ Conj ثم MP مع 1: $GDPRApplies = 1$. الخطوة 2: بـ MP مع 2: $ConsentRequired = 1$. الخطوة 3: بـ Conj مع $\neg ConsentLogged$: الشرط كامل $\Longrightarrow$ بـ MP مع 3: $Violation = 1$.

النتيجة: نعم، انتهاك مؤكَّد. الربط بالذكاء الاصطناعي: «الذكاء الاصطناعي القابل للتفسير والتدقيق» (auditable AI) يحتاج سلاسل استدلال من هذا النوع: كل قرار يجب أن يُرفق بمسار اشتقاق قابل للمراجعة القانونية.

مثال (15-5.1): إثبات عدم الإرضاء بمحرّك (Resolution SAT (Refutation

المعطيات: الصيغة $\Gamma = \{(A \vee B),\ (\neg A \vee C),\ (\neg B),\ (\neg C)\}$. المطلوب: أثبت بالاستيعاب أن Γ غير قابلة للإرضاء.

الحل: الخطوة 1: من $(A \vee B)$ و $(\neg B)$ بالاستيعاب الوحدوي (26.1): A. الخطوة 2: من $(\neg A \vee C)$ و A: C. الخطوة 3: من C و $(\neg C)$: $\square$ (فقرة فارغة). الخطوة 4: الوصول إلى $\square$ يعني التناقض $\Gamma \models \bot \implies$.

النتيجة: الصيغة غير قابلة للإرضاء. (UNSAT) الربط بالذكاء الاصطناعي: محرّكات SAT الحديثة (CDCL) تُعمّم هذه الخطوة إلى ملايين الفقرات، وتُستخدم في التحقق من الشبكات العصبية (مثل إثبات متانة adversarial robustness) وفي الجدولة والتخطيط.

6.6.1 أخطاء شائعة

الخطأ	الصواب
من $P \to Q$ و Q استنتاج P	هذه مغالطة «إثبات التالي» (affirming the consequent)
من $P \to Q$ و $\neg P$ استنتاج $\neg Q$	مغالطة «نفي السابق» (denying the antecedent)
اعتبار $P \to Q$ سببية	لزوم مادي فقط؛ السببية تحتاج $do(\cdot)$
الخلط بين $\vdash$ و $\models$	الأول اشتقاق آلي، الثاني صحة دلالية؛ يجمعهما (28.1)
ظنّ أن الاستيعاب يحتاج حرفين متضادّين فقط	نعم يحتاجهما، والنتيجة فصل الباقي

صُمّمت التمارين على ثلاثة مستويات: (أ) تطبيق مباشر، (ب) تركيب، (ج) تحدٍّ بحثي-تطبيقي. الإجابات المختصرة في نهاية القسم.

المستوى (أ) — تطبيق مباشر

١. بسّط: $\neg(\neg P \vee Q)$ بصيغة لا تحتوي نفياً مزدوجاً.

٢. بسّط: $\neg(A \wedge (B \vee C))$ إلى صيغة على OR/AND مع نفي على الرموز فقط.

٣. في فصلٍ من 60 طالباً: 35 يدرسون الرياضيات و 30 الفيزياء و 12 الاثنتين. كم لا يدرس أيّاً منهما؟

٤. احسب $|A \cup B \cup C|$ إن كانت الأحجام 100 و 80 و 60، والأزواج 30 و 20 و 15، والثلاثي 8.

٥. أثبت بالاستقراء: $\sum_{i=1}^{n} i = \frac{n(n+1)}{2}$.

٦. أثبت بالاستقراء: $\sum_{i=1}^{n} 2^i = 2^{n+1} - 2$.

٧. كم عدداً من الأشخاص يلزم لضمان أن ثلاثة منهم وُلدوا في الشهر ذاته؟

٨. 25 كتاباً على 6 رفوف: أثبت وجود رفٍّ بـ ≥ 5 كتب.

٩. من $(P \to Q)$ و $(Q \to R)$ و P، استنتج R مبيناً القاعدة المستخدمة في كل خطوة.

١٠. حوّل القاعدة $(A \wedge B) \to C$ إلى CNF.

المستوى (ب) — تركيب

١. في مجموعة بيانات 50,000 صورة: معيارات الجودة ثلاثة بأحجام 45,000 و 40,000 و 42,000، والأزواج 36,000 و 38,000 و 34,000، والثلاثي 31,000. احسب الصور الصالحة.

٢. أثبت بالاستقراء القوي أن كل عدد صحيح $n \geq 2$ يكتب كجداء أعداد أولية.

٣. استخدم مبدأ الحمام لإثبات أن أي خوارزمية فرز بالمقارنة... (تلميح: اربط بعدد التبديلات $n!$ وعدد أشجار القرار الممكنة).

٤. أثبت أن $\neg(P \oplus Q) \equiv (P \leftrightarrow Q)$.

٥. أثبت صحة قاعدة الاستيعاب (25.1) بجدول صدق كامل.

٦. أثبت أن $\big((P \to Q) \wedge (Q \to R)\big) \to (P \to R)$ قضية دائمة الصدق (tautology).

٧. أثبت بالاستقراء أن عدد حواف الرسم البياني الكامل K_n هو $\frac{n(n-1)}{2}$.

٨. في شبكة من 500 عقدة و 1,000 وصلة: أثبت وجود عقدة درجتها ≥ 4 بالاستقراء... بل بمبدأ الحمام على مجموع الدرجات.

٩. أثبت بالاستقراء أن $n^3 + 2n$ يقبل القسمة على 3 لكل $n \in \mathbb{N}$.

١٠. استخدم الشمول والاستبعال لإثبات صيغة عدد التبديلات التي لا تُثبّت أي عنصر (derangements) $D_n = n! \sum_{k=0}^{n} \frac{(-1)^k}{k!}$.

المستوى (ج) — تحدٍّ

١. بيّن أن الاستقراء الضعيف (12.1) والقوي (13.1) متكافئان منطقياً.

٢. أثبت بمبدأ حسن الترتيب أن كل كسر $\frac{a}{b}$ يمكن تبسيطه إلى أبسط صورة.

٣. صِغ «مبدأ الحمام الاحتمالي»: إن كان $n > m$ فاحتمال خلوّ صندوق مختار عشوائياً من التصادم $\leq \ldots$ وبيّن حدّه.

٤. في نموذج لغة بقاموس حجمه $|V| = 50{,}000$ ومساحة تضمين $d = 128$: استخدم مبدأ الحمام لمناقشة إمكانية تضمين «لا تصادمي» للكلمات.

٥. أثبت أن قاعدة الاستيعاب مع وحدات فقط تكفي لإثبات أي نتيجة من قاعدة معرفة على شكل قواعد Horn (وهو أساس Prolog).

٦. بيّن أن دي مورغان يعمّم على المنطق الضبابي بـ t-norms: متى يصحّ ومتى يفشل؟

٧. استخدم مبدأ الحمام لإثبات أن لا يوجد ضغط بدون فقد يقلّص **كل** الملفات (بصيغة دقيقة).

٨. أثبت بالاستقراء البنيوي أن كل شجرة ثنائية بحث صحيحة تُنتج ترتيباً تصاعدياً عند المسح بالترتيب (in-order).

٩. في شبكة عصبية بـ L طبقة واتصالات متبقّية اختيارية: أثبت بالاستقراء أن عدد الشبكات الفرعية الممكنة 2^L، وناقش أثر ذلك على التعميم.

١٠. صُمّم قاعدة معرفة من 5 قواعد Horn لنظام كشف احتيال، ثم أثبت بالاستيعاب أن حالةً محدّدة تُصنَّف «احتيال».

إجابات مختصرة

#	الإجابة
1	$P \wedge \neg Q$
2	$(\neg A \vee \neg B) \wedge (\neg A \vee \neg C) \iff \neg A \vee (\neg B \wedge \neg C)$
3	$60 - (35 + 30 - 12) = 7$
4	$240 - 65 + 8 = 183$
5	الأساس $n=1$: ✓ 1؛ الخطوة: $\frac{k(k+1)}{2} + (k+1) = \frac{(k+1)(k+2)}{2}$
6	الأساس $n=1$: ✓ 2؛ الخطوة: $(2^{k+1} - 2) + 2^{k+1} = 2^{k+2} - 2$
7	$2 \times 12 + 1 = 25$ شخصاً
8	$\lceil 25/6 \rceil = 5$
9	HS ثم MP (مرتين)
10	$\neg A \vee \neg B \vee C$
11	$127{,}000 - 108{,}000 + 31{,}000 = 50{,}000$ (كلها صالحة)
12	إن كان n أولياً انتهى، وإلا $n = ab$ مع $a, b < n$ فبالفرض القوي كلٌّ منهما جداء أوليّات
13	$n!$ تبديلات تحتاج شجرة قرار بـ $\geq n!$ ورقة؛ ارتفاعها $\geq \log_2(n!) = \Omega(n \log n)$
14	جدول صدق: يتطابقان في الصفوف الأربعة
15	أربع صفوف؛ في كل صف تصدق المقدّمتان تصدق $Q \vee R$
16	الصيغة كاذبة فقط لو $P=1, Q=1, R=0$... تحقق: الصفوف الثمانية كلها 1
17	الأساس $n=1$: ✓ 0؛ الخطوة: K_{k+1} يضيف k حواف
18	مجموع الدرجات $= 2 \times 1000 = 2000$؛ المتوسط $= 4 \implies$ عقدة بدرجة ≥ 4
19	الأساس $n=0$: ✓ 0؛ الخطوة: $(k+1)^3 + 2(k+1) - (k^3 + 2k) = 3k^2 + 3k + 3$ يقبل القسمة على 3
20	الشمول والاستبعال على أحداث «العنصر i مثبّت»
21	بتعريف $Q(n) = \forall j \leq n : P(j)$، فالاستقراء الضعيف على Q يعطي القوي والعكس بديهي
22	اختر أصغر بسط موجب بين الكسور المكافئة
23	$\mathbb{P}$(تصادم) $\geq 1 - \frac{m!}{m^n}\binom{m}{n} n!$ (صيغة عيد الميلاد المعمّمة)
24	التضمين في $\mathbb{R}^{128}$ متصل؛ لا تصادم ممكن نظرياً لكن تمييزها يعتمد على بعد المسافات
25	كل قاعدة Horn = clause بـliterals موجبة $\leq 1 \implies$ الاستيعاب يحفظ هذه الخاصية
26	يصحّ مع t-norms مزدوجة من t-conorm متوافقة (مثل min/max، وجداء/مجموع احتمالي)
27	انظر مثال (3-4.1) مع تعميم على أطوال متفاوتة
28	ورقة ✓؛ عقدة: اليسار أصغر واليمين أكبر بالفرض $\implies$ المسح مرتّب
29	كما في مثال (12-3.1)
30	مفتوح — صمّمه وأرسله للمراجعة

القانون	الصيغة المحورية	متى تستخدمه
دي مورغان	$\neg(P \wedge Q) \equiv \neg P \vee \neg Q$	تبسيط الشروط المنفية، CNF/DNF دوائر منطقية
الشمول والاستبعاد	$\lvert\cup A_i\rvert = \sum \lvert A_i\rvert - \sum \lvert A_i \cap A_j\rvert + \cdots$	العدّ والاحتمال مع تداخلات
الاستقراء الرياضي	$P(n_0) \wedge [P(k) \Rightarrow P(k+1)] \Rightarrow \forall n\, P(n)$	إثبات صحة/تعقيد خوارزميات متكرّرة
مبدأ الحمام	$\exists j : \lvert A_j\rvert \geq \lceil n/m \rceil$	حدود دنيا مضمونة وإثبات الاستحالة
قواعد الاستدلال والاستيعاب	$\dfrac{P \vee Q,\ \neg P \vee R}{Q \vee R}$؛ $\Gamma \vdash \varphi \iff \Gamma \models \varphi$	محرّكات الاستدلال و SAT

الخيط الناظم: كل هذه القوانين هي طرقٌ لمعالجة **البنى المنفصلة** — وهي اللغة التي تُكتب بها الخوارزميات والمعرفة. في الفصل القادم ننتقل إلى البنى **المتصلة**: الفضاءات المتجهة، حيث تعيش بيانات الذكاء الاصطناعي فعلياً.

الرمز	المعنى	القسم
$\neg,\ \wedge,\ \vee,\ \oplus$	نفي، عطف، فصل شامل، فصل حصري	1.1
$\rightarrow,\ \leftrightarrow,\ \equiv$	لزوم، تكافؤ (رابط)، تكافؤ (علاقة)	1.1
$\top,\ \bot$	صدق دائم، كذب دائم	1.1
$\vdash,\ \models,\ \Gamma,\ \varphi$	اشتقاق، لزوم دلالي، قاعدة معرفة، هدف	6.1
$\Omega,\ \omega,\ \in,\ \subseteq$	فضاء العوالم، عالم، انتماء، مجموعة فرعية	1.1
$\cup,\ \cap,\ ^c,\ \setminus$	اتحاد، تقاطع، متمّم، طرح	2.1
$\lvert A\rvert,\ \mathbb{P}(\cdot)$	عدد العناصر، الاحتمال	3.1
$\forall,\ \exists,\ \forall x,\ \exists x$	كمّيات شاملة ووجودية	2.1
$\lceil\cdot\rceil,\ \lfloor\cdot\rfloor$	سقف، أرضية	5.1
$\mathbb{N},\ n_0,\ k,\ j$	الأعداد الطبيعية، الأساس، مرتبة الاستقراء	4.1
$\sum,\ \binom{n}{k}$	مجموع، توافيق	3.1
$\square$	الفقرة الفارغة (تناقض)	6.1
$O(\cdot),\ T(n)$	ترميز التعقيد، دالة التكلفة	4.1

١. **Norvig & Russell** — *Artificial Intelligence: A Modern Approach*, Ch. 7–9 (المنطق القضيوي والمحمول والاستدلال).

٢. **Rosen** — *Discrete Mathematics and Its Applications*, Ch. 1–2, 5 (المنطق، المجموعات، الاستقراء).

٣. **Robinson (1965)** — *A Machine-Oriented Logic Based on the Resolution Principle* — الورقة المؤسِّسة لقاعدة الاستيعاب.

٤. **Biere et al.** — *Handbook of Satisfiability* — محرّكات SAT الحديثة (CDCL).

٥. **Vapnik** — *Statistical Learning Theory* — للربط بين مبدأ الحمام والسعة/بُعد VC (يُفصَّل في الفصل 31).

الفصل القادم: الفضاءات المتجهة والاستقلال الخطي — حيث تصبح البيانات «نقاطاً» والخوارزميات «تحويلات».

الفصل ٢

الفضاءات المتجهة، الاستقلال الخطي، والهندسة الداخلية

الشعار: «البيانات في الذكاء الاصطناعي ليست جداول؛ إنها **نقاط في فضاء متجهي**. وكل خوارزمية هي حركةٌ هندسية في ذلك الفضاء: إسقاط، تدوير، أو تقريب.»

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. التحقق من أن بنيةً ما فضاءً متجهي، وتحديد **بعدها** وأسسها.

٢. تطبيق **لامّة التبادل (شتاينيتز)** لحساب أبعاد الفضاءات الجزئية واتحادها وتقاطعها.

٣. استخدام **متراجحة كوشي–شفارتس** لضبط حدود التشابه والتدرّجات وثوابت ليبشيتز.

٤. حساب **الإسقاط المتعامد** كأفضل تقريب، وفهمه بوصفه الانحدار الخطي والـ PCA وضغط النماذج.

٥. بناء أساس متعامد بـ **غرام–شميدت** واستخراج **تحليل QR**.

٦. استخدام **نظرية الرتبة والعدمية** لتشخيص انهيار الرتبة وتحديد المعلمات الفعّالة.

المتطلبات المسبقة

الفصل الأول (المنطق والمجموعات والبرهان). لا يُفترض معرفة مسبقة بالجبر الخطي.

خريطة الفصل

القسم	النظرية/القانون	عدد الأمثلة المحلولة
1.2	الفضاء المتجهي: البديهيات والنتائج الفورية	—
2.2	**لامّة التبادل لشتاينيتز وثبات البُعد**	15
3.2	**متراجحة كوشي–شفارتس ومتراجحة المثلث**	15
4.2	**نظرية الإسقاط المتعامد وأفضل تقريب**	15
5.2	**غرام–شميدت والتحليل QR**	15
6.2	**نظرية الرتبة والعدمية**	15
7.2	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

Steinitz · Dimension · Basis · Span · Independence Linear · Subspace · Field · Space Vector · Projection Orthogonal · Inequality Cauchy–Schwarz · Product Inner · Lemma Exchange / Image · Space Null / Kernel · Theorem Rank–Nullity · Decomposition QR · Gram–Schmidt Range

1.1.2 التعريف الرسمي

الفضاء المتجهي على حقل $\mathbb{F}$ (عملياً $\mathbb{R}$ أو $\mathbb{C}$) هو مجموعة V مزوّدة بعمليتين — الجمع $+ : V \times V \to V$ والضرب القياسي $\cdot : \mathbb{F} \times V \to V$ — تحقّق البديهيات الثماني:

$$\forall\, u, v, w \in V: \quad (u + v) + w \;=\; u + (v + w) \tag{A1}$$

$$\forall\, u, v \in V: \quad u + v \;=\; v + u \tag{A2}$$

$$\exists\, \mathbf{0} \in V:\ \forall v \in V: \quad v + \mathbf{0} \;=\; v \tag{A3}$$

$$\forall v \in V,\ \exists (-v) \in V: \quad v + (-v) \;=\; \mathbf{0} \tag{A4}$$

$$\forall\, \alpha, \beta \in \mathbb{F},\ \forall v \in V: \quad \alpha(\beta v) \;=\; (\alpha\beta) v \tag{A5}$$

$$\forall v \in V: \quad 1 \cdot v \;=\; v \tag{A6}$$

$$\forall \alpha \in \mathbb{F},\ \forall u, v \in V: \quad \alpha(u + v) \;=\; \alpha u + \alpha v \tag{A7}$$

$$\forall\, \alpha, \beta \in \mathbb{F},\ \forall v \in V: \quad (\alpha + \beta) v \;=\; \alpha v + \beta v \tag{A8}$$

2.1.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة تطبيقية
V	الفضاء المتجهي	مجموعة العناصر (متجهات) مع عمليتين	في ML: فضاء التمثيل/الميزات
$\mathbb{F}$	الحقل	$\mathbb{R}$ (حقيقي) أو $\mathbb{C}$ (مركّب)	$\mathbb{R}$ هو المعتاد
u, v, w	متجهات	عناصر V	عيّنة، تضمين، صورة
$\mathbf{0}$	المتجه الصفري	العنصر المحايد للجمع	تضمين «فارغ»
$-v$	المعاكس الجمعي	بحيث $v + (-v) = \mathbf{0}$	—
α, β	قياسات (scalars)	عناصر الحقل	معدّل تعلّم، وزن
$\mathbb{R}^n$	الفضاء الإقليدي n-البعد	المتجهات الحقيقية بطول n	متجه ميزات
$\mathbb{R}^{m \times n}$	فضاء المصفوفات	مصفوفات $m \times n$	أوزان طبقة
$\operatorname{span}(S)$	التوليد	أصغر فضاء جزئي يحتوي S	فضاء الحلول الممكنة
$U \le V$	فضاء جزئي	مغلقة على العمليتين U	فضاء كامن (latent)
$\dim V$	البُعد	عدد عناصر أي أساس	عدد الميزات/القنوات
$\oplus$	الجمع المباشر	$V = U \oplus W$ مع $U \cap W = \{0\}$	تحليل متعامد

3.1.2 نتائج فورية (تُثبت بخطوتين من البديهيات)

$$\alpha \cdot \mathbf{0} = \mathbf{0} \qquad (-1)\cdot v = -v; \qquad 0 \cdot v = \mathbf{0}; \qquad (-v) \text{ وحيد}; \qquad \mathbf{0} \text{ وحيد}; \tag{0.2}$$

الربط بالذكاء الاصطناعي: لا تُخزَّن الصورة في الذاكرة كـ «صورة» بل كمتجه في $\mathbb{R}^{784}$ (صورة 28×28). والكلمة تُخزَّن كمتجه في $\mathbb{R}^{300}$. وبما أن العمليات هي جمع وضرب قياسي فقط، فإن كل خوارزمية تعلّم هي **تركيب خطي ثم لاخطية** — هذه هي البنية الكاملة للشبكة العصبية.

4.1.2 الاستقلال الخطي والأساس

مجموعة $\{v_1, \dots, v_k\}$ **مستقلة خطياً** إذا:

$$\sum_{i=1}^{k} \alpha_i v_i = \mathbf{0} \quad \Longrightarrow \quad \alpha_1 = \alpha_2 = \cdots = \alpha_k = 0 \tag{1.2}$$

وهي **أساس** لـ V إذا كانت مستقلة و تولّد V:

$$\mathcal{B} = \{b_1, \dots, b_n\} : \quad \operatorname{span}(\mathcal{B}) = V \ \wedge \ \mathcal{B} \text{ مستقلة} \tag{2.2}$$

صاغها: إرنست شتاينيتز (1910). وهي النظرية التي تجعل كلمة «البُعد» ذات معنى: لا يمكن لفضاءٍ واحد أن يكون له بُعدان مختلفان.

1.2.2 الصياغة الرسمية

لامّة التبادل:

إذا كانت $\{v_1, \dots, v_m\}$ تولّد V، وكانت $\{w_1, \dots, w_k\}$ مستقلةً خطياً في V، فإن:

$$k \ \le \ m \tag{3.2}$$

ويمكن استبدال k من المتجهات v_i بالمتجهات w_j مع الحفاظ على التوليد.

نتيجة — ثبات البُعد:

$$\mathcal{B}_1,\ \mathcal{B}_2 \text{ أساسان لـ } V \implies |\mathcal{B}_1| = |\mathcal{B}_2| \ =: \ \dim V \tag{4.2}$$

نتيجة — صيغة الفضاءين الجزئيين:

$$\dim(U + W) \ = \ \dim U \ + \ \dim W \ - \ \dim(U \cap W) \tag{5.2}$$

$$U \cap W = \{\mathbf{0}\} \implies \dim(U \oplus W) \ = \ \dim U + \dim W \tag{6.2}$$

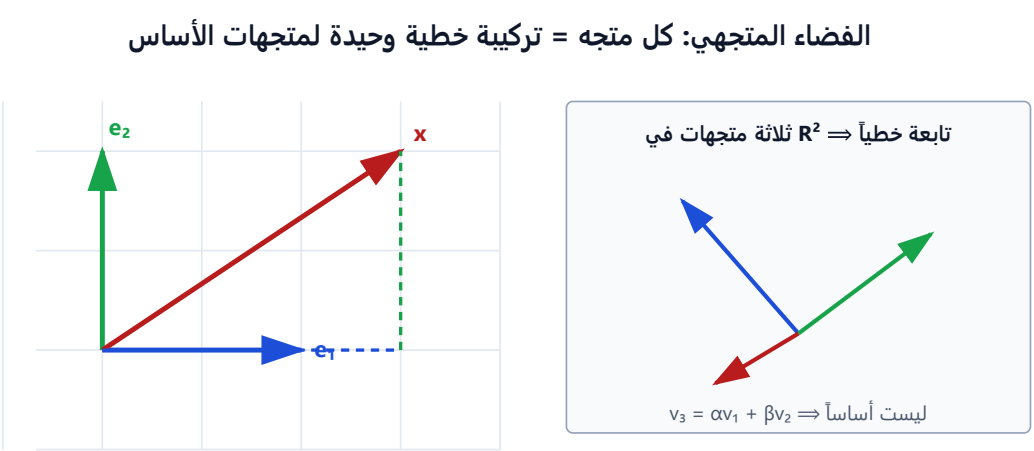
نتيجة — الحدود العملية:

$$\dim \operatorname{span}\{v_1, \dots, v_k\} \ \le \ k, \qquad \text{وفي } \mathbb{R}^n : \ \text{أي } n+1 \text{ متجه تابعة خطياً} \tag{7.2}$$

2.2.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى	ملاحظة
m	عدد المولّدات	حجم المجموعة التي تولّد V	حدّ أعلوي للبُعد
k	عدد المستقلّة	حجم المجموعة المستقلة	حدّ أدنوي للبُعد
$\lvert\mathcal{B}\rvert$	عدد عناصر الأساس	$\dim V$ =	—
$U + W$	مجموع الفضاءين	$\{u + w : u \in U,\ w \in W\}$	ليس necessarily مباشراً
$U \cap W$	التقاطع	ما يشتركان فيه	سبب الطرح في (5.2)
$\oplus$	الجمع المباشر	مجموع بتقاطع صفري	التباس: لا يُطرح شيء
rank	الرتبة	بُعد فضاء الأعمدة	= بُعد الصورة
span	التوليد	جميع التركيبات الخطية	—

3.2.2 الشكل الهندسي



شكل (2.1): الأساس = أصغر مجموعة تولّد الفضاء، وأكبر مجموعة مستقلة فيه؛ عددها = البُعد

شكل ١.٢: *
الفضاء المتجهي والأساس

شكل (1.2): يساراً: كل متجه x تركيبة خطية وحيدة من $\{e_1, e_2\}$. يميناً: ثلاثة متجهات في $\mathbb{R}^2 \implies$ تابعة بالضرورة (باللامّة 3.2 مع $k = 3 > m = 2$).

4.2.2 البرهان

لامّة التبادل:

نُثبت بالإحلال المتدرّج. بما أن $\{v_i\}$ تولّد V والمجموعة $\{w_j\}$ مستقلة، فإن $w_1 \neq \mathbf{0}$ (وإلا لكانت تابعة)، فـ $w_1 = \sum_i c_i v_i$ مع بعض $c_{i_1} \neq 0$. نحلّ المعادلة فنعوّض عن v_{i_1} بـ w_1 ومضاعفات الـ v الأخرى $\implies$ المجموعة الجديدة ما زالت تولّد V.

نكرّر للمتجه w_2: لو كان w_2 تركيبةً من v المتبقية فقط، لكان تركيبةً من $\{w_1\}$ المتبقية وv... بالتفصيل: في كل خطوة نستهلك مولّداً واحداً ونضيف متجهاً مستقلاً واحداً. لو نفدت المولّدات قبل استيعاب كل w_j (أي $k > m$)، لكان أحد الـ w المتبقية تركيبةً خطية لـ w المضافة سابقاً $\implies$ تناقض مع الاستقلال. إذن $k \leq m$. ■

ثبات البُعد (4.2): إذا كان $\mathcal{B}_1$ أساساً (مولّد) و $\mathcal{B}_2$ أساساً (مستقل)، فباللاّمة: $|\mathcal{B}_1| \leq |\mathcal{B}_2|$؛ وبتبادل الدورين: $|\mathcal{B}_2| \leq |\mathcal{B}_1| \implies$ التساوي.

5.2.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-1.2): بُعد فضاء ميزات جدول بيانات

المعطيات: جدول فيه 12 عموداً: 10 ميزات رقمية + عمود «المدينة» (8 مدن) مشفّر one-hot + عمود هدف. المطلوب: بُعد فضاء الميزات بعد الترميز.

الحل: الخطوة 1: 10 ميزات رقمية $\implies$ 10 أبعاد. الخطوة 2: one-hot لـ 8 مدن $\implies$ 8 أعمدة، لكن مجموعها $1 =$ $\implies$ التابع خطياً موجود $\implies$ الاستقلال يعطي $7 = 1 - 8$ أبعاد فعّالة (أو 8 في فضاء الميزات الخام). الخطوة 3: الإجمالي $18 = 8 + 10 =$ بعداً خاماً (أو 17 بعد إسقاط التبعية).

النتيجة: $18 =$ dim خاماً / 17 فعّالاً. الربط بالذكاء الاصطناعي: هذا هو مصدر **فخّ المتغيّر الوهمي** (dummy variable trap): التبعية الخطية تجعل مصفوفة $X^\top X$ غير قابلة للعكس $\implies$ الانحدار الخطي ينهار. الحل: إسقاط عمود واحد.

مثال (2-1.2): هل 300 بُعداً تكفي لتضمين الكلمات؟

المعطيات: قاموس $|V| = 100{,}000$ كلمة؛ تضمينات في $\mathbb{R}^{300}$. المطلوب: كم كلمة يمكن أن تكون مستقلة خطياً؟ وهل البعد كافٍ؟

الحل: الخطوة 1: في $\mathbb{R}^{300}$ أي 301 متجه تابعة خطياً (7.2). الخطوة 2: لكن عدد المتجهات **المستقلة** لا يحدّد التمييز العملي؛ المهم الزوايا: في $\mathbb{R}^d$ يمكن وضع $\approx e^{0.21d}$ متجهاً شبه متعامد (بزاوية $\geq 89°$). الخطوة 3: لـ $d = 300$: عدد ضخم $\gg 100{,}000 \implies$ كافٍ.

النتيجة: 300 بُعداً تكفي بوفرة لتمييز 100 ألف كلمة. الربط بالذكاء الاصطناعي: هذا هو التبرير الهندسي لنجاح word2vec/GloVe بأبعاد 100–300: ليس مطلوباً الاستقلال التام بل **التمييز الزاوي**، والفضاءات عالية البعد «متسعة» بشكل مضاد للحدس.

مثال (3-1.2): one-hot والبعد الفعّال

المعطيات: تصنيف من 5 أصناف بـ one-hot في $\mathbb{R}^5$، متوسط المجموع $1 =$. المطلوب: بُعد الفضاء الجزئي (affine) الذي تعيش فيه هذه المتجهات.

الحل: الخطوة 1: القيد $\sum_i x_i = 1$ هو معادلة خطية واحدة غير صفرية $\implies$ يخفض البعد بمقدار 1. الخطوة 2: الفضاء الجزئي الخطي المولّد من الفروق له بُعد $4 = 1 - 5$. الخطوة 3: المتجهات الخمس (one-hot) مستقلة **تآلفياً** لا خطياً: $\sum_{i=1}^{5} e_i \cdot 1 \ldots$ بل المتجهات نفسها مستقلة خطياً (5 متجهات في $\mathbb{R}^5$ تشكّل أساساً)، لكن **المدى** يقع في مستوٍ تآلفي بأبعاد 4.

النتيجة: البعد التآلفي 4، والبعد الخطي 5. الربط بالذكاء الاصطناعي: التمييز بين «بعد خطي» و«بعد تآلفي» يظهر في هندسة **logits** الشبكة: زيادة ثابتة لكل logits لا تغيّر softmax $\Longrightarrow$ الفضاء الفعّال أبعاده $C-1$.

مثال (2.1-4): اختيار عدد المركبات في PCA

المعطيات: بيانات في $\mathbb{R}^{50}$، نريد فضاءً جزئياً U يحفظ 95% من التباين. المطلوب: العلاقة بين $\dim U$ والتباين المفقود.

الحل: الخطوة 1: المتجهات k الأولى components Principal تولّد فضاءً جزئياً U بـ $\dim U = k$. الخطوة 2: الباقي في $U^{\perp}$ ببعد $50 - k$. الخطوة 3: التباين المفقود = مجموع القيم الذاتية على $U^{\perp}$. الخطوة 4: نختار أصغر k يحقّق $\sum_{i>k}\lambda_i / \sum_i \lambda_i \le 0.05$.

النتيجة: k = أول موضع يتجاوز فيه التباين التراكمي 95%. الربط بالذكاء الاصطناعي: اختيار k هو تحديد **بُعد الفضاء الكامن الفعّال**، وهو ما يُسمّى «intrinsic dimension» لمتعدّد البيانات (manfiold).

مثال (2.1-5): عدد الطبقات مقابل سعة التمثيل

المعطيات: شبكة بـ L طبقة مخفية عرضها h، التفعيلات في كل طبقة عناصر من $\mathbb{R}^h$. المطلوب: كم «منطقة خطية» يمكن أن تخلقها الشبكة في المدخل $\mathbb{R}^d$؟

الحل: الخطوة 1: كل خليةReLU تقسم الفضاء بنصف مستوٍ $\Longrightarrow$ الطبقة الأولى تخلق h نصف-مستوٍ. الخطوة 2: عدد المناطق الخطية لترتيب h مستوٍ في $\mathbb{R}^d$ هو $\sum_{i=0}^{d}\binom{h}{i} = O(h^d)$. الخطوة 3: مع L طبقة يتضاعف العدد أُسّياً مع L: $O\big((h^d)^L\big)$ في أسوأ تحليل.

النتيجة: السعة تنمو أُسّياً مع العمق. الربط بالذكاء الاصطناعي: هذا هو التفسير الحديث لتفوّق العمق على العرض: **العمق يضاعف السعة التركيبية** لا مجرد عدد المعلمات.

مثال (2.1-6): LoRA وفضاء التحديث منخفض الرتبة

المعطيات: وزن طبقة $W_0 \in \mathbb{R}^{m\times n}$، التحديث $\Delta W = BA$ مع $B \in \mathbb{R}^{m\times r}$، $A \in \mathbb{R}^{r\times n}$، $r \ll \min(m,n)$. المطلوب: بُعد فضاء التحديثات الممكنة.

الحل: الخطوة 1: ΔW يقع في فضاء المصفوفات ذات الرتبة $\le r$. الخطوة 2: بُعد فضاء المصفوفات $m \times n$ ذات الرتبة $\le r$ هو $r(m+n) - r^2$. الخطوة 3: عند $m = n = 4096$ و $r = 8$: $8(8192) - 64 = 65{,}472$ من أصل $16{,}777{,}216$ معلمة (0.39%).

النتيجة: يُدرَّب أقل من 0.4% من المعلمات. الربط بالذكاء الاصطناعي: الفرضية الضمنية: تحديثات الضبط الدقيق تعيش في **فضاء جزئي منخفض البعد** — وهذا تطبيق مباشر لمفهوم البُعد الجوهري.

مثال (2.1-7): حين يكون عدد العيّنات أقل من البعد

المعطيات: 40 عيّنة في $\mathbb{R}^{200}$ (مثل بيانات جينومية). المطلوب: هل يمكن أن تكون مصفوفة البيانات $X \in \mathbb{R}^{40\times 200}$ ذات رتبة كاملة؟

الحل: الخطوة 1: رتبة المصفوفة $\leq \min(40, 200) = 40$. الخطوة 2: بـ (7.2): صفوف X (العيّنات) 40 متجهاً في $\mathbb{R}^{200}$ $\Longrightarrow$ مستقلة ممكن، لكن الأعمدة 200 متجهاً في $\mathbb{R}^{40}$ $\Longrightarrow$ **تابعة حتماً**. الخطوة 3: إذن توجد تركيبات خطية غير تافهة بين الميزات $\Longrightarrow$ $X^\top X$ منفردة.

النتيجة: النظام غير محدّد $\Longrightarrow$ يلزم تنظيم (Ridge) أو تقليل أبعاد. الربط بالذكاء الاصطناعي: هذه هي الحالة $p \gg n$ الشائعة في الطب الحيوي، وتفسّر لماذا ينهار الانحدار squares least ordinary ويجب استخدام Lasso/Ridge.

مثال (2.1-8): بُعد فضاء القنوات في CNN

المعطيات: طبقة التفافية مخرجاتها خريطة ميزات $64 \times 56 \times 56$. المطلوب: بُعد فضاء التمثيل عند كل موقع مكاني، والبعد الكلي.

الحل: الخطوة 1: عند كل موقع: متجه في $\mathbb{R}^{64} \Longrightarrow \dim = 64$. الخطوة 2: البعد الكلي لخريطة الميزات $= 56 \times 56 \times 64 = 200{,}704$. الخطوة 3: لكن فضاء **القنوات** المشترك بين المواقع بُعده 64 (النواة مشتركة مكانياً).

النتيجة: 200,704 خلية لكن البعد الدلالي 64. الربط بالذكاء الاصطناعي: هذا الفرق هو سرّ كفاءة الشبكات الالتفافية: **مشاركة الأوزان** تقيّد الفضاء إلى فضاء جزئي منخفض البعد من فضاء الاتصال الكامل.

مثال (2.1-9): الترميز الموضعي في المحوّلات

المعطيات: نموذج ببعد $d_{model} = 768$، طول السياق 2048، الترميز الموضعي يُضاف للتضمين. المطلوب: هل الجمع يخرج من فضاء التضمين؟

الحل: الخطوة 1: $x = e_{\text{token}} + p_{\text{pos}}$ مع كلٍّ في $\mathbb{R}^{768}$. الخطوة 2: الجمع مغلق في الفضاء (بديهية A1/A2) $\Longrightarrow$ الناتج في $\mathbb{R}^{768}$ ذاته. الخطوة 3: البعد لا يتغيّر، لكن الفضاء المتاح يتوسّع لأن الترميز الموضعي يكسر التماثل.

النتيجة: البعد ثابت 768، والمعلومات تزداد. الربط بالذكاء الاصطناعي: في الترميز الموضعي النسبي الحديث (RoPE) يُطبَّق **تدوير** وليس جمعاً $\Longrightarrow$ التدوير إسometric فيحفظ الأطوال، وهي ميزة عددية كبيرة.

مثال (2.1-10): الاستشعار المضغوط

المعطيات: إشارة $x \in \mathbb{R}^{1000}$ متناثرة: 10 عناصر غير صفرية فقط $(k = 10)$. المطلوب: كم قياساً m نحتاج لاستعادتها؟

الحل: الخطوة 1: x تعيش في اتحاد فضاءات جزئية: $\bigcup_{S:|S|=10} \mathbb{R}^{10}_S$ – اتحاد $\binom{1000}{10}$ فضاءً جزئياً بُعد كلٍّ منها 10. الخطوة 2: كل فضاء جزئي بُعده 10 $\Longrightarrow$ لتمييزه داخل فضاء القياسات نحتاج $m \geq 10$. الخطوة 3: النظرية الدقيقة: $m = O(k\log(n/k)) = O(10\log 100) \approx 100$ قياساً $\Longrightarrow$ ضغط ×10.

النتيجة: ≈ 100 قياساً بدل 1000. الربط بالذكاء الاصطناعي: نفس الفكرة تُستخدم لضغط تحديثات التدرّج في التعلّم الاتحادي (Federated Learning) وإرسال «أهم 1%» فقط.

مثال (2.1-11): عدد الخلايا مقابل رتبة التمثيل

المعطيات: طبقة مخفية بـ h خليةReLU على مدخل $\mathbb{R}^d$. المطلوب: ما أقصى رتبة لمصفوفة التفعيلات على N عيّنة؟

الحل: الخطوة 1: مصفوفة التفعيلات $H \in \mathbb{R}^{N\times h} \Longrightarrow$ رتبتها $\leq \min(N,h)$. الخطوة 2: إذا كان $h < N$ فالتمثيلات كلها تعيش في فضاء جزئي بُعده $\leq h$ من $\mathbb{R}^N$. الخطوة 3: هذا قيدٌ على قدرة الطبقة على «فصل» العيّنات (linear separability in feature space).

النتيجة: الرتبة $\leq h$. الربط بالذكاء الاصطناعي: ظاهرة **«رتبة التمثيل المنهارة»** (representation rank collapse) في الشبكات العميقة تُقاس بهذه الرتبة؛ وهي مؤشر على فقدان التنوّع بين العيّنات.

مثال (2.1-12): بُعد فضاء الصور

المعطيات: صور رمادية 28×28 من MNIST. المطلوب: بُعد فضاء الصور، والبعد الجوهري للمتعدّد الذي تقع عليه.

الحل: الخطوة 1: الفضاء المحيط $\mathbb{R}^{784}$. الخطوة 2: الصور «الحقيقية» لا تملأ الفضاء، بل تقع على متعدّد بُعده $\approx$ 10–15 (تُقدَّر بالـ PCA أو بمقدّر MLE للبعد الجوهري). الخطوة 3: الفرق $784 - 15 = 769$ بُعداً «ضجيج/فراغ».

النتيجة: البعد الجوهري ≈ 15 من أصل 784. الربط بالذكاء الاصطناعي: **فرضية المتعدّد** (manfiold hypothesis): بيانات العالم الحقيقي تعيش على متعدّد منخفض البعد، وهذا ما يبرّر نجاح التعلّم بالتمثيلات وأجهزة التشفير الذاتية (autoencoders).

مثال (2.1-13): hashing feature والاستقلال

المعطيات: 5,000 ميزة أصلية تُضغط بـ hashing إلى 500 بُعداً. المطلوب: هل تحفظ العملية الاستقلال الخطي؟

الحل: الخطوة 1: $x \mapsto Hx$ مع $H \in \mathbb{R}^{500\times 5000} \Longrightarrow$ الرتبة ≤ 500. الخطوة 2: أي 501 ميزة أصلية مستقلة تصبح **تابعة** بالضرورة بعد الضغط (7.2). الخطوة 3: لكن بمتراجحة Johnson–Lindenstrauss تُحفظ المسافات تقريباً إذا كان $500 = O(\log N/\varepsilon^2)$.

النتيجة: الاستقلال يُفقد، والمسافات تُحفظ تقريباً. الربط بالذكاء الاصطناعي: **درس منهجي:** الحفاظ على المسافات (JL) غير الحفاظ على الاستقلال، ومعظم تعلّم الآلة يحتاج الأول لا الثاني.

مثال (2.1-14): تضمينات المستخدمين في نظام توصية

المعطيات: 10 ملايين مستخدم، تضمينات في $\mathbb{R}^{64}$. المطلوب: كم «محوراً دلالياً» مستقلاً يمكن ترميزه؟

الحل: الخطوة 1: البعد 64 $\Longrightarrow$ 64 اتجاهاً مستقلاً على الأكثر. الخطوة 2: عدد النقاط المميّزة بفصل زاوي مريح في $\mathbb{R}^{64}$ $2^{64} \approx$ نظرياً، وعملياً ملايين عدّة. الخطوة 3: لكن **السعة الدلالية** محدودة بـ 64 محوراً $\Longrightarrow$ مميّزات مثل (عمر، قوة شرائية، نوع المحتوى، وقت النشاط...) تتقاسم الأبعاد.

النتيجة: 64 محوراً دلالياً فحسب. الربط بالذكاء الاصطناعي: اختيار بُعد التضمين مقايضة: بعد أكبر $\Longrightarrow$ سعة أعلى وتعميم أسوأ (overfitting) وتكلفة استرجاع أعلى؛ القاعدة العملية $d \approx \sqrt[4]{|\text{الكيانات}|}$.

مثال (2.1-15): تقليل رتبة التدرّجات في التدريب الموزّع

المعطيات: تدرّج طبقة $G \in \mathbb{R}^{4096\times4096}$، نضغطه برتبة $r = 4$ (PowerSGD) قبل الإرسال بين العقد. المطلوب: حجم البيانات المرسَلة ونسبة الضغط.

الحل: الخطوة 1: الحجم الأصلي $4096\times4096 = 16{,}777{,}216$ رقماً. الخطوة 2: التخزين برتبة r: $P \in \mathbb{R}^{4096\times4}$ و $Q \in \mathbb{R}^{4\times4096}$ $\Longrightarrow$ $2 \times 4096 \times 4 = 32{,}768$. الخطوة 3: النسبة $32768/16{,}777{,}216 \approx 0.00195$ $\Longrightarrow$ ضغط $\times512$.

النتيجة: إرسال 0.2% فقط من الحجم. الربط بالذكاء الاصطناعي: الفرضية: تدرّجات التدريب تقع قريباً من فضاء جزئي منخفض الرتبة؛ وهذا تطبيق مباشر لنظرية البعد على **اتصالات** التدريب الموزّع.

6.2.2 أخطاء شائعة

الخطأ	الصواب
«n متجه في $\mathbb{R}^n$ $\Longrightarrow$ مستقلة»	العكس غير صحيح؛ الاستقلال يحتاج فحص المحدّد/الرتبة
الخلط بين المتجهات والفضاء التآلفي	one-hot تعيش في مستوٍ تآلفي لا فضاء خطي
ظنّ أن البعد = عدد المعلمات	البعد = عدد عناصر الأساس؛ المعلمات قد تكون مكرّرة/تابعة
افتراض $\dim(U+W) = \dim U + \dim W$	اطرح $\dim(U\cap W)$ كما في (5.2)

الأهمية: هذه ليست مجرد متراجحة في كتاب جبر، إنها **الأداة التي تُنتج كل حدود الذكاء الاصطناعي**: حدود التعميم، ثوابت ليبشيتز، استقرار التدرّج، وتشابه المتجهات في الاسترجاع الدلالي.

1.3.2 الصياغة الرسمية

متراجحة كوشي–شفارتس (Cauchy–Schwarz): في أي فضاء جداء داخلي:

$$|\langle u,\, v\rangle| \;\le\; \|u\|\,\|v\| \tag{8.2}$$

صيغة الزاوية (التي تُستخدم فعلياً):

$$\cos\theta \;=\; \frac{\langle u,\, v\rangle}{\|u\|\,\|v\|} \;\in\; [-1,\,1] \tag{9.2}$$

حالة التساوي:

$$\big|\langle u, v\rangle\big| = \|u\|\,\|v\| \iff u = \alpha v \text{ أو } v = \mathbf{0} \text{ أو } u = \mathbf{0} \tag{10.2}$$

الصيغة الاحتمالية (متراجحة كوشي–شفارتس للتوقّع):

$$\big(\mathbb{E}[XY]\big)^2 \;\le\; \mathbb{E}[X^2]\,\mathbb{E}[Y^2] \tag{11.2}$$

متراجحة المثلث:

$$\|u+v\| \;\le\; \|u\| + \|v\|, \qquad \big|\|u\| - \|v\|\big| \le \|u - v\| \tag{12.2}$$

الصيغة الماتريسية (متراجحة الناظم الفرعي Sub-multiplicativity — تُعمَّم لاحقاً):

$$\|Ax\| \;\le\; \|A\|_{\mathrm{op}}\,\|x\| \;\le\; \|A\|_F\,\|x\| \tag{13.2}$$

2.3.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
$\langle u, v\rangle$	الجداء الداخلي	$u^{\top}v = \sum_i u_i v_i$	مقياس التشابه الخام
$\|u\|$	الناظم (المدى)	$\sqrt{\langle u, u\rangle}$ = طول المتجه	ناظم L_2
θ	الزاوية بين المتجهين	arccos للنسبة في (9.2)	—
$\cos\theta$	تشابه جيب التمام	في $[-1, 1]$؛ 1= نفس الاتجاه $\Longrightarrow$	cosine_similarity
$[-1, 1]$	مجال التشابه	ناتج مباشر من (8.2)	—
$\mathbb{E}[\cdot]$	التوقّع	المتوسط الاحتمالي	الفصل 15
$\|A\|_{\mathrm{op}}$	الناظم التشغيلي	$\max_{\|x\|=1}\|Ax\|$ = أكبر قيمة مفردة σ_1	الفصل 5
$\|A\|_F$	ناظم فروبنيوس	$\sqrt{\sum_{ij} A_{ij}^2}$	يسهل حسابه
σ_1	أكبر قيمة مفردة	جذر أكبر قيمة ذاتية لـ $A^{\top}A$	مفتاح الاستقرار
α	قياس التناسب	في حالة التساوي (10.2)	استقامة خطية

3.3.2 الشكل الهندسي

شكل (2.2): يساراً: $\langle u, v\rangle = \|u\|\|v\|\cos\theta$، وبما أن $|\cos\theta| \le 1$ تنتج (8.2). يميناً: الضلع المستقيم $\|a+b\|$ أقصر من مجموع الضلعين.

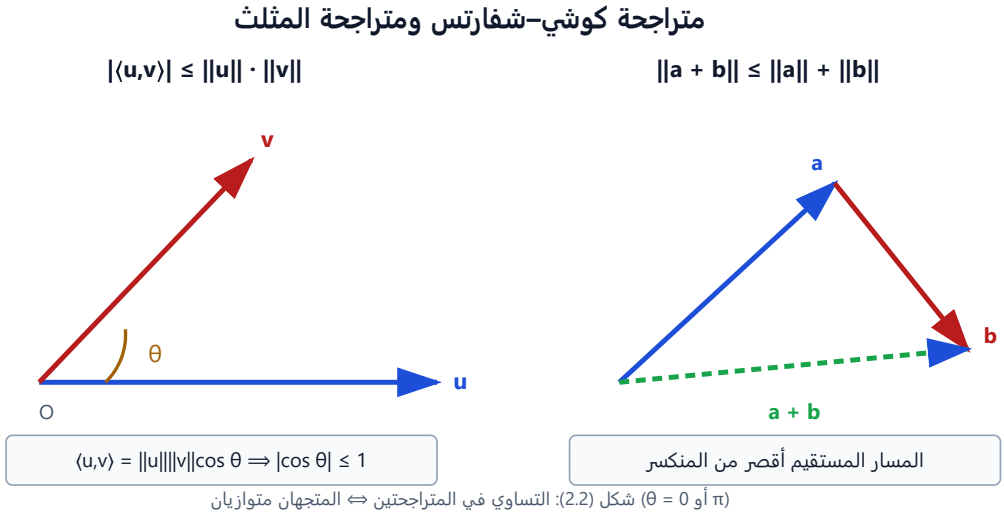
4.3.2 البرهان

كوشي–شفارتس: لكل $\lambda \in \mathbb{R}$، بإيجابية الناظم:

$$0 \;\le\; \|u - \lambda v\|^2 \;=\; \langle u - \lambda v,\; u - \lambda v\rangle \;=\; \|u\|^2 - 2\lambda\langle u, v\rangle + \lambda^2\|v\|^2$$

هذا كثيرُ حدود تربيعي في λ غير سالب $\Longrightarrow$ مميّزه $\le$ صفر (أو نختار $\lambda = \langle u, v\rangle/\|v\|^2$ الذي يصغّره):

$$\arg\min_{\lambda} \;=\; \frac{\langle u, v\rangle}{\|v\|^2} \;\Longrightarrow\; \|u\|^2 - \frac{\langle u, v\rangle^2}{\|v\|^2} \;\ge\; 0 \;\Longrightarrow\; \langle u, v\rangle^2 \le \|u\|^2\|v\|^2$$



شكل ٢.٢: *
كوشي–شفارتس ومتراجحة المثلث

بأخذ الجذر: (8.2)• والتساوي $\|u-\lambda v\|=0 \iff u=\lambda v$ (10.2)• ■
متراجحة المثلث: نربع الطرفين:

$$\|u+v\|^2=\|u\|^2+2\langle u,v\rangle+\|v\|^2 \overset{(2.8)}{\leq} \|u\|^2+2\|u\|\|v\|+\|v\|^2=\big(\|u\|+\|v\|\big)^2$$

5.3.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (2.2-1): تشابه جيب التمام بين تضمينين

المعطيات: $u=(0.6,\,0.8)$، $v=(0.8,\,0.6)$• المطلوب: $\cos\theta$ بينهما، والتحقق من (8.2)•
الحل: الخطوة 1: $\langle u,v\rangle = 0.6\cdot0.8+0.8\cdot0.6 = 0.48+0.48 = 0.96$• الخطوة 2: $\|u\| = \sqrt{0.36+0.64}=1$، $\|v\| = \sqrt{0.64+0.36}=1$• الخطوة 3: $\cos\theta = 0.96/(1\cdot1) = 0.96 \Longrightarrow$ $\theta\approx16.3^\circ$• الخطوة 4: تحقق: $0.96\leq1\cdot1$ ✓•
النتيجة: تشابه عالٍ 96.0 (متجهان متقاربان)• الربط بالذكاء الاصطناعي: هذا هو مقياس الترتيب القياسي في استرجاع المستندات (dense retrieval)؛ الانحراف البسيط يعني «مرادفان» في فضاء التضمين•

مثال (2.2-2): حدّ أعلى على درجات الانتباه

المعطيات: في آلية الانتباه: $\text{score}_{ij}=\frac{q_i^\top k_j}{\sqrt{d}}$ مع $\|q_i\|=3$، $\|k_j\|=5$، $d=64$• المطلوب: أقصى درجة ممكنة•
الحل: الخطوة 1: بـ (8.2): $|q_i^\top k_j|\leq 3\cdot5=15$• الخطوة 2: القسمة على $\sqrt{64}=8 \Longrightarrow |\text{score}|\leq 15/8=1.875$• الخطوة 3: التباين الأقصى لـ softmax = $e^{3.75}\approx42.5$ $\exp(1.875-(-1.875))$•
النتيجة: أقصى نسبة وزنين = 5.42• الربط بالذكاء الاصطناعي: هذا يفسّر **سبب القسمة على** $\sqrt{d}$: بدونها تنفجر الدرجات مع بُعد التضمين فيصبح softmax شبه one-hot ويتلاشى التدرّج•

مثال (2.2-3): حدّ أعلى على ناظم التدرّج

المعطيات: طبقة خطية $z = W^\top x$، $\|x\| = 10$، $\|W\|_F = 2$. المطلوب: حدّ أعلى على $\|\nabla_W \mathcal{L}\|$ إن كان $|\partial \mathcal{L}/\partial z| \le 0.5$.

الحل: الخطوة 1: $\nabla_W \mathcal{L} = x \cdot (\partial \mathcal{L}/\partial z)^\top \Rightarrow \|\nabla_W \mathcal{L}\|_F = \|x\| \cdot |\partial \mathcal{L}/\partial z|$. الخطوة 2: $10 \times 0.5 = 5$. الخطوة 3: تحقق بـ (2.13): النتيجة مستقلة عن $\|W\|_F$ لأن التدرّج على الأوزان يعتمد على المدخل فقط.

النتيجة: $\|\nabla_W \mathcal{L}\| \le 5$. الربط بالذكاء الاصطناعي: هذا الحدّ هو ما يجعل **قصّ التدرّج** (gradient clipping) قابلاً للضبط: نعرف سلفاً مقدار النمو المتوقّع.

مثال (2.2-4): حدّ على ثابت ليبشيتز لطبقة خطية

المعطيات: طبقة $f(x) = Wx$ مع $\|W\|_{\text{op}} = 4$. المطلوب: هل f ليبشيتزية بثابت 4؟ وما أثر ذلك على المتانة؟

الحل: الخطوة 1: $\|f(x) - f(y)\| = \|W(x-y)\| \overset{(2.13)}{\le} \|W\|_{\text{op}} \|x - y\| = 4\|x - y\|$. الخطوة 2: إذن الثابت $L = 4$. الخطوة 3: اضطراب $\|\delta\| = 0.1$ في المدخل $\Rightarrow$ اضطراب ≤ 0.4 في المخرج.

النتيجة: الشبكة 4-ليبشيتزية. الربط بالذكاء الاصطناعي: ثابت ليبشيتز هو المقياس الرسمي لـ **المتانة ضد الأمثلة الخصامية** (adversarial robustness)؛ الطبقات ذات $\|W\|_{\text{op}}$ صغير أكثر متانة، ومنه تقنيات التطبيع الطيفي (spectral normalization).

مثال (2.2-5): هامش SVM وحدّ التعميم

المعطيات: مصنّف خطي $f(x) = \text{sign}(w^\top x)$، $\|w\| = 2$، كل العيّنات $\|x\| \le 5$ ومصنّفة بهامش $w^\top x \ge 1$. المطلوب: حدّ أدنى للهامش الهندسي.

الحل: الخطوة 1: الهامش الهندسي $= \frac{|w^\top x|}{\|w\|}$. الخطوة 2: الحدّ الأدنى $0.5 = 1/2$. الخطوة 3: تحقق بـ (8.2): $|w^\top x| \le 2 \cdot 5 = 10 \Rightarrow$ الهامش ≤ 5 دائماً (مربوط).

النتيجة: الهامش الهندسي $\in [0.5, 5]$. الربط بالذكاء الاصطناعي: حدّ التعميم الكلاسيكي: خطأ الاختبار $\le$ خطأ التدريب + $O\left(\frac{R^2}{\gamma^2 \sqrt{n}}\right)$ حيث R ناظم المدخل و γ الهامش $\Rightarrow$ تكبير الهامش يقلّل فرط التخصيص.

مثال (2.2-6): تنظيم الأوزان وحدّ المخرج

المعطيات: $\|w\|_2 \le 1$ (تنظيم L_2 قوي)، مدخل $\|x\|_2 = 8$. المطلوب: أقصى قيمة مطلقة لـ logit.

الحل: الخطوة 1: بـ (8.2): $|w^\top x| \le 1 \cdot 8 = 8$. الخطوة 2: التساوي يتحقّق فقط إذا كان $x \parallel w$ وبنفس الاتجاه (10.2). الخطوة 3: عملياً الزوايا عشوائية $\Rightarrow$ القيمة المتوقّعة أصغر بكثير: $\mathbb{E}|w^\top x| \approx \|w\|\|x\|/\sqrt{d}$.

النتيجة: الحدّ الأقصى 8، القيمة العملية $8/\sqrt{d} \approx$ ٠. الربط بالذكاء الاصطناعي: هذا هو التفسير الكمّي لأثر weight decay: تصغير $\|w\|$ يصغّر مباشرةً سعة المخرجات $\Longrightarrow$ دالة أنعم $\Longrightarrow$ تعميم أفضل.

مثال (٢.٢-7): تبييض الميزات وارتباط القنوات

المعطيات: ميزتان a, b بتباين 1 ومعامل ارتباط $\rho = 0.9$. المطلوب: التعبير عن الارتباط كجداء داخلي وتحديد مداه.

الحل: الخطوة 1: بعد التوحيد (متوسط 0، تباين 1): $\langle a, b \rangle = \mathbb{E}[ab] = \rho$. الخطوة 2: بـ (٢.١١): $\rho^2 \leq 1 \cdot 1 = 1 \Longrightarrow \mathbb{E}[a^2]\mathbb{E}[b^2] = 1 \Longrightarrow |\rho| \leq 1$ ✓. الخطوة 3: $\rho = 0.9 \Longrightarrow$ الزاوية $\theta = \arccos(0.9) = 25.8°$ $\Longrightarrow$ الميزتان شبه متوازيتين.

النتيجة: الميزتان تحملان معلومات متداخلة بنسبة 81% من التباين. الربط بالذكاء الاصطناعي: التطبيع الدفعي (BatchNorm) وتبييض الميزات يهدفان إلى إزالة هذا التوازي $\Longrightarrow$ تسرّع التقارب لأن سطح الخسارة يصبح أكثر استدارة.

مثال (٢.٢-8): حدّ على تغيّر الخسارة بخطوة تدرّج

المعطيات: $\|\nabla \mathcal{L}\| = 3$؛ خطوة تحديث $\|\Delta\theta\| = 0.01$ بعكس اتجاه التدرّج. المطلوب: حدّ أعلى على تغيّر الخسارة من الدرجة الأولى.

الحل: الخطوة 1: التغيّر من الدرجة الأولى: $\Delta\mathcal{L} \approx \langle \nabla\mathcal{L},\ \Delta\theta \rangle$. الخطوة 2: بـ (٢.٨): $|\Delta\mathcal{L}| \leq 3 \times 0.01 = 0.03$. الخطوة 3: وبما أن الخطوة عكس التدرّج: $\Delta\mathcal{L} \approx -0.03$ (انخفاض).

النتيجة: انخفاض $\leq$ ٠.٠٣ لكل خطوة. الربط بالذكاء الاصطناعي: العلاقة $\Delta\mathcal{L} \leq \eta\|\nabla\|^2$ هي الأساس في إثبات تقارب SGD: نحتاج η صغيراً كفاية لضمان الانخفاض الرتيب.

مثال (٢.٢-9): نمو التدرّج في الشبكات المتكرّرة

المعطيات: RNN: $h_t = \tanh(Wh_{t-1})$؛ $\|W\|_{\text{op}} = 1.5$؛ ناظم الحالة $\|h_0\| = 1$. المطلوب: حدّ على نمو التدرّج بعد $T = 20$ خطوة.

الحل: الخطوة 1: بـ (٢.١٣): $\|Wh\| \leq \|W\|_{\text{op}}\|h\| \leq 1.5\|h\|$. الخطوة 2: بعد T خطوة: $\|h_T\| \leq 1.5^T = 1.5^{20} \approx 3325$. الخطوة 3: التدرّج العكسي يتراكم بنفس العامل $\Longrightarrow$ انفجار.

النتيجة: يُضرب التدرّج بعامل يصل إلى 3325. الربط بالذكاء الاصطناعي: هذا هو التشخيص الكلاسيكي لمشكلة **انفجار/تلاشي التدرّج**؛ والحلول (LSTM/GRU gates، قصّ التدرّج، التطبيع الطيفي) كلها تهدف إلى جعل $\|W\|_{\text{op}} \approx 1$.

مثال (٢.٢-10): حدّ التشابه في استرجاع RAG

المعطيات: استعلام $\|q\| = 1$ بـ q؛ مستند $\|d\| = 1$ بـ d؛ نطاق درجات الاسترجاع. المطلوب: هل يمكن أن تتجاوز الدرجة 1؟ ولماذا تُقسَّم التضمينات؟

الحل: الخطوة 1: بـ (8.2): $|q^\top d| \le 1 \cdot 1 = 1$. الخطوة 2: التساوي $\iff q = d$ تماماً (10.2). الخطوة 3: عملياً تُطبَّع التضمينات (L2-normalize) لتكون $\|\cdot\| = 1 \implies$ الدرجة = $\cos\theta$ مباشرة.

النتيجة: الدرجات $\in [-1, 1]$ بالضبط. الربط بالذكاء الاصطناعي: التطبيع يجعل البحث في الفهرس متريّاً (inner product = cosine)؛ (index وهو شرط لعمل فهارس HNSW و IVF بكفاءة.

مثال (2.2-11): تعارض التدرّجات في التعلّم متعدد المهام

المعطيات: تدرّجان $\|g_1\| = 4$، $\|g_2\| = 6$؛ جداؤهما $\langle g_1, g_2\rangle = -18$. المطلوب: الزاوية بينهما، وهل يتعارضان؟

الحل: الخطوة 1: $\cos\theta = -18/(4 \cdot 6) = -18/24 = -0.75$. الخطوة 2: تحقق من (8.2): $|-18| = 24 \le 18$ ✓. الخطوة 3: $\theta = \arccos(-0.75) \approx 138.6° \implies$ زاوية منفرجة $\implies$ تعارض قوي.

النتيجة: تعارض واضح؛ تحديث أحدهما يضرّ الآخر. الربط بالذكاء الاصطناعي: خوارزميات PCGrad و Gradient Surgery تُسقط تدرّجاً على المتمّم المتعامد للآخر عندما يكون $\cos\theta < 0$ — تطبيق مباشر للإسقاط الذي سنراه في 4.2.

مثال (2.2-12): حدّ على خسارة InfoNCE في التعلّم التبايُني

المعطيات: تضمينات مُطبَّعة $\|v\| = \|u\| = 1$؛ درجة الإيجاب $s_+ = u^\top v = 0.7$؛ درجة السلب الأقصى $s_- = 0.3$؛ درجة الحرارة $\tau = 0.1$؛ عدد السلوب 1000. المطلوب: حدّ أدنى لخسارة InfoNCE.

الحل: الخطوة 1: $\mathcal{L} = -\log \frac{e^{s_+/\tau}}{e^{s_+/\tau} + \sum_i e^{s_i^-/\tau}}$. الخطوة 2: أسوأ حالة: كل السلوب عند أقصى درجة $0.3 \implies$ $1000 \times 0.0183 = \implies e^{-4} = 0.0183$:3 الخطوة .$\mathcal{L} \ge \log\big(1 + 1000\, e^{(0.3-0.7)/0.1}\big) = \log(1 + 1000\, e^{-4})$ $\mathcal{L} \ge \log(19.3) = 2.96 \implies 18.3$.

النتيجة: $\mathcal{L} \ge 2.96$ في أسوأ حالة. الربط بالذكاء الاصطناعي: (8.2) يضمن أن كل الدرجات في $[-1, 1] \implies$ الفرق الأقصى $2/\tau \implies$ عدد السلوب المطلوب لخسارة صغيرة جداً يحدَّد مسبقاً.

مثال (2.2-13): حدّ على ناظم مخرج الانتباه

المعطيات: $\mathrm{Attn}(Q, K, V) = \mathrm{softmax}(QK^\top/\sqrt{d})\, V$؛ A مصفوفة الأوزان (صفوفها توزيعات احتمالية)؛ $\|V\|_{\mathrm{op}} = 3$. المطلوب: حدّ أعلى على ناظم المخرج.

الحل: الخطوة 1: صفوف A توزيعات $\implies \|A\|_\infty = 1$ و $\|A\|_{\mathrm{op}} \le \sqrt{n}$ (لـ n صفوف). الخطوة 2: $\|AV\|_{\mathrm{op}} \le \|A\|_{\mathrm{op}} \|V\|_{\mathrm{op}}$ بـ (13.2). الخطوة 3: $\sqrt{n} \times 3 =$؛ ومع $n = 512$: $67.9 =$.

النتيجة: المخرج مربوط بـ $3\sqrt{n}$. الربط بالذكاء الاصطناعي: هذا يفسّر الحاجة إلى **التوصيلات المتبقّية والتطبيع الطبقي**: بدونها تنمو أنظار المخرج مع طول السياق فتنهار dynamica التدريب.

مثال (2.2-14): متانة التضمينات أمام الضجيج

المعطيات: تضمين x بـ $\|x\| = 2$، ضجيج δ بـ $\|\delta\| = 0.2$، ناظم الأوزان $\|w\| = 1$. المطلوب: أقصى تغيّر في المخرج.

الحل: الخطوة 1: التغيّر $|w^\top(x+\delta) - w^\top x| = |w^\top \delta| \le \|w\|\|\delta\| = 1 \times 0.2 =$ (8.2): الخطوة 2: بـ 0.2. الخطوة 3: نسبة التغيّر إلى المخرج الأقصى $|w^\top x| \le 2 \implies$ 10%.

النتيجة: تغيّر $\le 10\%$ من المخرج. الربط بالذكاء الاصطناعي: تحليل الحساسية هذا هو حجر الأساس في **الخصوصية التفاضلية** (DP): إضافة ضجيج بمقدار مضبوط يحدّد تسريب المعلومات بدقة قابلة للإثبات.

مثال (2.2-15): متراجحة التباين بالصيغة الاحتمالية

المعطيات: متغيّر انحياز النموذج B بتباين 0.04، متغيّر الضجيج E بتباين 0.25، معامل ارتباط ρ. المطلوب: أقصى تغاير ممكن بينهما.

الحل: الخطوة 1: بـ (11.2): $\operatorname{Cov}(B,E)^2 \le \operatorname{Var}(B)\operatorname{Var}(E) = 0.04 \times 0.25 = 0.01$. الخطوة 2: $\implies |\operatorname{Cov}| \le 0.1$. الخطوة 3: تباين الخطأ الكلي $= 0.04 + 0.25 + 2\operatorname{Cov} \le 0.29 + 0.2 = 0.49$.

النتيجة: تباين الخطأ $\in [0.09,\ 0.49]$. الربط بالذكاء الاصطناعي: هذه هي **تحليل الانحياز–التباين–الضجيج**؛ حدّ كوشي–شفارتس على التغاير هو ما يجعل تحليل التحيز–التباين قابلاً للحساب (الفصل 30).

6.3.2 أخطاء شائعة

الخطأ	الصواب
مقارنة cos دون تطبيع الأطوال	$\langle u, v\rangle$ وحده لا يعطي تشابهاً
تطبيق (8.2) على متجهات غير مُطبَّعة وتفسير الناتج كزاوية	الناتج مقياس خام؛ اقسم على الناظمين
نسيان حالة التساوي	التساوي $\iff$ التوازي، وهي مفيدة في إثباتات الحدود
الخلط بين $\|A\|_{\text{op}}$ و $\|A\|_F$	الأول $\le$ الثاني؛ الأول هو الصحيح لحدود ليبشيتز

الأهمية في الذكاء الاصطناعي: هذه النظرية الواحدة تشرح في آنٍ واحد: **الانحدار الخطي، PCA، ضغط الصور، إزالة التحيز من التضمينات، إسقاط التدرّج في التعلّم المستمر، وترشيح كالمان.** كلها «أقرب نقطة في فضاء جزئي».

1.4.2 الصياغة الرسمية

نظرية الإسقاط:

ليكن $W \le V$ فضاءً جزئياً منتهي البعد. لكل $y \in V$ يوجد **وحيد** $\hat{y} \in W$ بحيث:

$$\hat{y} = \arg\min_{w \in W} \|y - w\| \qquad \iff \qquad (y - \hat{y}) \perp W \tag{14.2}$$

أي: $\langle y - \hat{y},\ w \rangle = 0$ لكل $w \in W$. ونكتب $\hat{y} = P_W\, y$.

صيغة الإسقاط الماتريسية: إذا كانت أعمدة $A \in \mathbb{R}^{n \times k}$ أساساً لـ W (أي $W = \mathrm{col}(A)$):

$$P_W \;=\; A\,(A^\top A)^{-1} A^\top \tag{15.2}$$

$$\hat{y} \;=\; P_W\, y \;=\; A\, x^\star, \qquad x^\star \;=\; (A^\top A)^{-1} A^\top y \tag{16.2}$$

المعادلات النظامية (Normal Equations):

$$A^\top A\, x^\star \;=\; A^\top y \tag{17.2}$$

خصائص مؤثّر الإسقاط:

$$P_W^2 = P_W \ \text{(انعكاسية)}, \qquad P_W^\top = P_W \ \text{(تماثل)}, \qquad \mathrm{eig}(P_W) \subseteq \{0, 1\} \tag{18.2}$$

متطابقة فيثاغورس:

$$\|y\|^2 \;=\; \|\hat{y}\|^2 \;+\; \|y - \hat{y}\|^2 \tag{19.2}$$

مترابحة بيسل (Bessel) ومتطابقة بارسيفال (Parseval): لأساس متعامد معياري $\{u_i\}_{i=1}^{n}$:

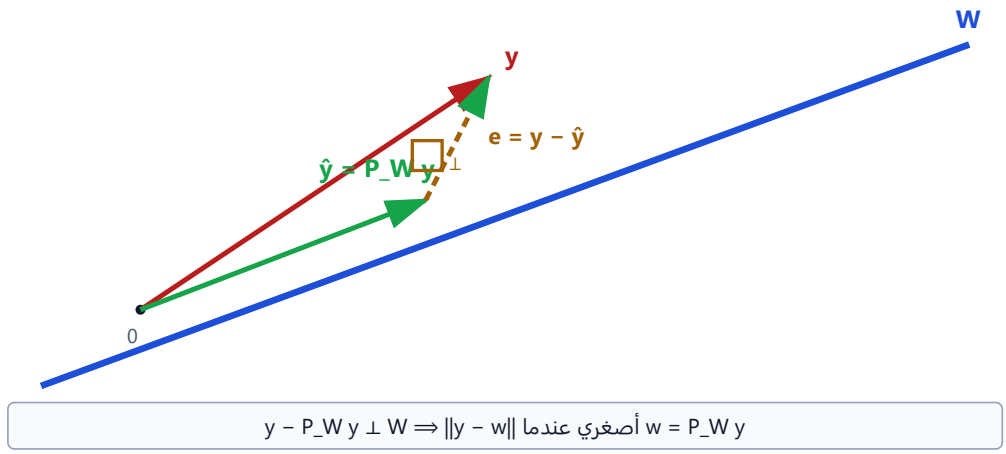
$$\sum_{i=1}^{k} \langle y, u_i \rangle^2 \;\le\; \|y\|^2 \quad (k < n), \qquad \sum_{i=1}^{n} \langle y, u_i \rangle^2 \;=\; \|y\|^2 \tag{20.2}$$

2.4.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
W	فضاء جزئي	فضاء الحلول/النموذج	subspace
P_W	مؤثّر الإسقاط	مصفوفة $n \times n$ تماثلية انعكاسية	matrix projection
$\hat{y}$	الإسقاط/التقدير	أقرب نقطة في W إلى y	y_hat
$e = y - \hat{y}$	الباقي/المخلف	الخطأ الذي لا تستطيع W تمثيله	residual
$\perp$	التعامد	$\langle a, b \rangle = 0$	—
$A^\top A$	مصفوفة غرام	متماثلة موجبة نصف-محددة	عكسها قد يكون غير مستقر
$x^\star$	المعاملات المثلى	حلّ المربعات الصغرى	coefficients
$\arg\min$	مُصغِّر الدالة	النقطة التي تحقّق الأصغريّة	—
eig	مجموعة القيم الذاتية	هنا $\{0, 1\}$	الفصل 4
$\|\cdot\|$	ناظم L_2	الجذر التربيعي لمجموع المربعات	—

3.4.2 الشكل الهندسي

شكل (3.2): المتجه $e = y - \hat{y}$ عمودي على $W \Longrightarrow$ أي حركة داخل W تزيد المسافة (بفيثاغورس). هذا هو معنى «أفضل تقريب».



شكل ٣.٢: *
الإسقاط المتعامد

4.4.2 البرهان

الخطوة 1 — أن الشرط المتعامد يلزم للأصغرية: ليكن $w \in W$ أيّاً. نكتب:

$$y - w \;=\; \underbrace{(y-\hat{y})}_{e} \;+\; \underbrace{(\hat{y}-w)}_{\in W}$$

وبما أن $e \perp W$ و $(\hat{y}-w) \in W$ $\Longrightarrow$ المتجهان متعامدان $\Longrightarrow$ بفيثاغورس:

$$\|y-w\|^2 \;=\; \|e\|^2 \;+\; \|\hat{y}-w\|^2 \;\geq\; \|e\|^2 \;=\; \|y-\hat{y}\|^2$$

والتساوي $\Longleftrightarrow \|\hat{y}-w\|=0 \Longleftrightarrow w=\hat{y}$ $\Longrightarrow$ الأصغرية والوحدانية.

الخطوة 2 — وجود متجه يحقّق التعامد: نطلب $\langle y-Ax,\; a_j\rangle = 0$ لكل عمود a_j من A:

$$A^{\top}(y-Ax) = \mathbf{0} \;\Longrightarrow\; A^{\top}A\,x = A^{\top}y$$

وهو نظام (17.2). وإذا كانت أعمدة A مستقلة فـ $A^{\top}A$ موجبة التحديد $\Longrightarrow$ قابلة للعكس $\Longrightarrow$ $x^{\star}$ وحيد $\Longrightarrow$ (16.2). ■

5.4.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (3.2-1): الانحدار الخطي البسيط كإسقاط

المعطيات: ثلاث نقاط $(1,2),\ (2,3),\ (3,5)$؛ نريد أنسب خط $y = \beta_0 + \beta_1 t$. المطلوب: إيجاد (β_0,β_1) وإثبات أنها إسقاط.

الحل: الخطوة 1: $A = \begin{bmatrix}1 & 1\\ 1 & 2\\ 1 & 3\end{bmatrix}$، الخطوة 2: $y = \begin{bmatrix}2\\3\\5\end{bmatrix}$. $A^{\top}A = \begin{bmatrix}3 & 6\\ 6 & 14\end{bmatrix}$، $A^{\top}y = \begin{bmatrix}10\\23\end{bmatrix}$. الخطوة 3:

نحلّ: $3\beta_0 + 6\beta_1 = 10$، $6\beta_0 + 14\beta_1 = 23$ $\Longrightarrow$ من الأولى ضعفها: $6\beta_0 + 12\beta_1 = 20$ $\Longrightarrow$ بالطرح: $2\beta_1 = 3$ $\Longrightarrow$ $\beta_1 = 1.5$. الخطوة 4: $\beta_0 = (10 - 9)/3 = 1/3$. الخطوة 5: الباقي $e = y - A\beta = (2 - 1.833,\ 3 - 3.333,\ 5 - 4.833) = (0.167,\ -0.333,\ 0.167)$، وتحقق $A^\top e = (0,\ 0)$ ✓ تعامد.

النتيجة: $\hat{y} = 0.333 + 1.5\,t$. الربط بالذكاء الاصطناعي: هذا هو الانحدار الخطي بالمعنى الهندسي: لا توجد «خوارزمية» سوى إيجاد أقرب نقطة من y إلى فضاء الأعمدة $\mathrm{col}(A)$.

مثال (2-3.2): توقّع أسعار المنازل بميزات متعدّدة

المعطيات: 100 منزل، ميزات: المساحة، عدد الغرف، بُعد عن المركز؛ $A \in \mathbb{R}^{100\times 4}$ (مع عمود ثابت). المطلوب: صيغة الحلّ وعدد المعاملات.

الحل: الخطوة 1: $\mathrm{col}(A) = W$، $\dim W = 4$ (بفرض استقلال الأعمدة). الخطوة 2: الحلّ $\beta^\star = (A^\top A)^{-1}A^\top y$. الخطوة 3: بُعد الباقي $= 100 - 4 = 96$ $\Longrightarrow$ الباقي له 96 درجة حرية.

النتيجة: 4 معاملات، 96 درجة حرية للخطأ. الربط بالذكاء الاصطناعي: درجات الحرية المتبقية تحدّد تقدير تباين الضجيج: $\hat{\sigma}^2 = \|e\|^2/(n-k)$، وهي التي تُستخدم في فترات الثقة.

مثال (3-3.2): PCA وخطأ إعادة الإعمار

المعطيات: نقطة $y \in \mathbb{R}^{50}$، نُسقطها على فضاء المركبتين الأوليين $U = \mathrm{span}\{u_1, u_2\}$، الإحداثيات $(4,\ 3)$؛ $\|y\| = 6$. المطلوب: ناظم الباقي ونسبة التباين المفسَّر.

الحل: الخطوة 1: $\|\hat{y}\|^2 = 4^2 + 3^2 = 25 \Longrightarrow \|\hat{y}\| = 5$ (لأن $\{u_1, u_2\}$ متعامد معياري). الخطوة 2: بفيثاغورس (19.2): $\|e\|^2 = 36 - 25 = 11 \Longrightarrow \|e\| = 3.317$. الخطوة 3: نسبة التباين المفسَّر $= 25/36 = 69.4\%$.

النتيجة: 69.4% مفسَّر، و 30.6% خطأ إعادة إعمار. الربط بالذكاء الاصطناعي: هذه هي بالضبط دالة خسارة الـ autoencoder الخطي: $\|y - \hat{y}\|^2$؛ والـ PCA هي الحلّ المغلق له.

مثال (4-3.2): ضغط الصور بإسقاط منخفض الرتبة

المعطيات: صورة رمادية 256×256 $\Longrightarrow$ مصفوفة $M \in \mathbb{R}^{256\times 256}$، نُبقي أول $k = 16$ مركبة مفردة. المطلوب: عدد الأرقام المخزَّنة ونسبة الضغط.

الحل: الخطوة 1: التخزين الكامل $= 256 \times 256 = 65{,}536$ رقماً. الخطوة 2: التخزين برتبة 16: $U_k\Sigma_k \in \mathbb{R}^{256\times 16}$ و $V_k^\top \in \mathbb{R}^{16\times 256}$ $\Longrightarrow$ $2 \times 256 \times 16 = 8{,}192$. الخطوة 3: النسبة $= 8192/65536 = 12.5\%$ $\Longrightarrow$ ضغط $\times 8$. الخطوة 4: الخطأ $= \sqrt{\sum_{i>16}\sigma_i^2}$ (بارسيفال المعمّم).

النتيجة: ضغط $\times 8$ مع خطأ قابل للقياس بدقة. الربط بالذكاء الاصطناعي: هذا هو أساس ضغط أوزان النماذج (SVD-based compression)، ونفس الفكرة تُستخدم لتقليل حجم نماذج اللغة الكبيرة بنسبة 30–50%.

مثال (2.3-5): تقريب دالة بمتعددة حدود

المعطيات: نقاط $\{(0,1),\ (1,3),\ (2,7),\ (3,13)\}$؛ نُقرّبها بمتعددة حدود من الدرجة 2: $p(t) = c_0 + c_1 t + c_2 t^2$. المطلوب: المعاملات بالمربعات الصغرى.

الحل: الخطوة 1: $A = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{bmatrix}$، $y = (1,3,7,13)^\top$. الخطوة 2: $A^\top A = \begin{bmatrix} 4 & 6 & 14 \\ 6 & 14 & 36 \\ 14 & 36 & 98 \end{bmatrix}$، $A^\top y = \begin{bmatrix} 24 \\ 56 \\ 146 \end{bmatrix}$. الخطوة 3: بحلّ النظام: $c_2 = 1$، $c_1 = 1$، $c_0 = 1$ (تحقق: $1 + t + t^2$ تعطي $1, 3, 7, 13$ ✓ تامة).

النتيجة: $p(t) = t^2 + t + 1$ بخطأ صفر. الربط بالذكاء الاصطناعي: تركيب الدوال بأساس متعامد (متعددات حدود ليجاندر/تشيبشيف) هو ما تفعله شبكات KAN الحديثة بدل الأوزان الثابتة.

مثال (2.3-6): توقّع المبيعات من الإنفاق الإعلاني

المعطيات: 6 أشهر: إنفاق $(1,2,3,4,5,6)$ ألف، مبيعات $(3,5,7,9,10,14)$ ألف. المطلوب: خط التوقع والمبيعات المتوقّعة عند إنفاق 7.

الحل: الخطوة 1: $\bar{t} = 3.5$، $\bar{y} = 8$. الخطوة 2: $\sum (t-\bar{t})(y-\bar{y}) = (-2.5)(-5) + (-1.5)(-3) + (-0.5)(-1) + (0.5)(1) + (1.5)(2) + (2.5)(6) = 12.5 + 4.5 + 0.5 + 0.5 + 3 + 15 = 36$. الخطوة 3: $\sum (t-\bar{t})^2 = 17.5 \Rightarrow \beta_1 = 36/17.5 = 2.057$. الخطوة 4: $\beta_0 = 8 - 2.057 \times 3.5 = 0.80$. الخطوة 5: عند $t = 7$: $\hat{y} = 0.80 + 2.057 \times 7 = 15.2$ ألف.

النتيجة: $\approx$ 15,200 وحدة. الربط بالذكاء الاصطناعي: هذا أبسط نموذج تنبؤي؛ كل نموذج تعليمي عميق هو تعميم مرن له: بدلاً من إسقاط على فضاء خطي، نسقط على فضاء **دوال** معلّمة.

مثال (2.3-7): إسقاط التدرّج في التعلّم متعدد المهام (PCGrad)

المعطيات: تدرّجان $g_1 = (1,\ 0)$، $g_2 = (-0.6,\ 0.8)$؛ $\langle g_1, g_2 \rangle = -0.6 < 0$. المطلوب: تعديل g_2 بإسقاطه على نصف الفضاء المتعامد على g_1.

الحل: الخطوة 1: نُسقط g_2 على اتجاه g_1: $\text{proj}_{g_1} g_2 = \frac{\langle g_2, g_1 \rangle}{\|g_1\|^2} g_1 = \frac{-0.6}{1}(1,0) = (-0.6,\ 0)$. الخطوة 2: نطرح المركّبة المتعارضة: $g_2^{\text{proj}} = g_2 - \text{proj}_{g_1} g_2 = (-0.6, 0.8) - (-0.6, 0) = (0,\ 0.8)$. الخطوة 3: تحقق التعامد: $\langle g_1,\ g_2^{\text{proj}} \rangle = 0$ ✓.

النتيجة: التحديث المجمّع $(1,\ 0.8)$ = لا يضرّ المهمة الأولى. الربط بالذكاء الاصطناعي: خوارزمية PCGrad تُطبّق هذا الشرط لكل زوج من المهام، وقد أثبتت تحسّناً ملموساً في التعلّم متعدد المهام والروبوتات.

مثال (2.3-8): الإسقاط على المبسط (Simplex) في التعلّم التعزيزي

المعطيات: متجه $v = (0.5,\ 0.3,\ 0.4)$؛ نريد إسقاطه على المبسط الاحتمالي $\Delta = \{p : \sum p_i = 1,\ p_i \geq 0\}$. المطلوب: أقرب توزيع احتمالي إلى v.

الحل: الخطوة 1: المجموع $= 1.2$؛ نطرح الزائد: نبحث θ بحيث $\sum \max(v_i - \theta,\ 0) = 1$. الخطوة 2: جرّب $\theta = 0.1$: $(0.4,\ 0.2,\ 0.3)$ $\Longrightarrow$ المجموع $= 0.9$ $\Longrightarrow$ θ كبير. الخطوة 3: جرّب $\theta = 0.05$: $(0.45, 0.25, 0.35)$ $\Longrightarrow$ المجموع $= 1.05$ $\Longrightarrow$ أصغر قليلاً. الخطوة 4: بالاستقراء: $\theta = 0.0667$ $\Longrightarrow$ $(0.4333,\ 0.2333,\ 0.3333)$ $\Longrightarrow$ المجموع $= 1.0$ ✓.

النتيجة: $p^\star = (0.433,\ 0.233,\ 0.333)$. الربط بالذكاء الاصطناعي: الإسقاط على المبسط يظهر في تحديثات السياسات الاحتمالية (TRPO/PPO) وفي خسارة الإنتروبيا؛ وله خوارزمية $O(n \log n)$ دقيقة.

مثال (2.3-9): ترشيح كالمان كإسقاط متكرّر

المعطيات: قياس $z = 10$، تقدير سابق $\hat{x}^- = 8$؛ تباينات: $P^- = 4$، $R = 1$. المطلوب: التقدير المحدَّث بربح كالمان.

الحل: الخطوة 1: ربح كالمان $K = \frac{P^-}{P^- + R} = \frac{4}{5} = 0.8$. الخطوة 2: $\hat{x} = \hat{x}^- + K(z - \hat{x}^-) = 8 + 0.8 \times 2 = 9.6$. الخطوة 3: التباين المحدَّث $P = (1 - K)P^- = 0.2 \times 4 = 0.8$. الخطوة 4: التفسير الهندسي: K هو وزن الإسقاط على المدى الجديد مقابل الفضاء السابق.

النتيجة: $\hat{x} = 9.6$ بتباين 0.8. الربط بالذكاء الاصطناعي: كالمان هو المربعات الصغرى المُعمَّمة على فضاء **حالات** زمنية؛ ويُستخدم اليوم في تتبّع الأجسام في القيادة الذاتية ودمج المستشعرات.

مثال (2.3-10): معايرة مستشعر حرارة بـ 3 قراءات

المعطيات: مستشعر يعطي $(20.1,\ 20.3,\ 19.8)$ عند درجة حرارة مرجعية معلومة 20.0. المطلوب: تقدير الانحياز والضجيج.

الحل: الخطوة 1: نموذج القياس: $z_i = \theta + \varepsilon_i$، أي $A = (1, 1, 1)^\top$، $W = \text{span}\{(1, 1, 1)\}$. الخطوة 2: الإسقاط: $\hat{\theta} = \frac{A^\top z}{A^\top A} = \frac{60.2}{3} = 20.067$، $e = (-0.033,\ 0.233,\ -0.267)$؛ $\|e\|^2 = 0.0011 + 0.0543 + 0.0713 = 0.127$. الخطوة 4: تباين الضجيج $= 0.127/2 = 0.063$ $\Longrightarrow$ انحراف معياري $\sigma \approx 0.25°$، ضجيج $\approx 0.25°$+. الربط بالذكاء الاصطناعي: تقدير الانحياز هو إسقاط على فضاء «الثوابت»، ونفس التقنية تُستخدم لمعايرة logits الشبكة (temperature scaling).

مثال (2.3-11): LoRA كإسقاط للتحديث على فضاء منخفض الرتبة

المعطيات: تحديث كامل $\Delta W \in \mathbb{R}^{4096\times4096}$ برتبة فعلية 2، القيم المفردة $(10,\ 4)$. المطلوب: أفضل تقريب برتبة 1 والخطأ.

الحل: الخطوة 1: بأقرب تقريب منخفض الرتبة (Eckart–Young، الفصل 4): نُبقي أكبر قيمة مفردة $\Rightarrow$ الرتبة 1. الخطوة 2: خطأ فروبنيوس $= \sqrt{\sum_{i>1}\sigma_i^2} = \sqrt{16} = 4$. الخطوة 3: الطاقة المحتفظ بها $= 100/(100+16) = 86.2\%$.

النتيجة: رتبة 1 تحفظ 86% من التحديث. الربط بالذكاء الاصطناعي: هذا يبرّر عملياً نجاح LoRA برتبة 1–8: تحديثات الضبط الدقيق مركّزة جداً طيفياً.

مثال (2.3-12): التعلّم المستمر بإسقاط التدرّج المتعامد (OGD)

المعطيات: المهمة 1 تعلّمت فضاءً جزئياً S ببعد 10 من أصل $d = 100$؛ تدرّج المهمة 2 هو $g \in \mathbb{R}^{100}$. المطلوب: تحديث لا يضرّ المهمة 1.

الحل: الخطوة 1: ليكن $U \in \mathbb{R}^{100\times10}$ أساساً متعاماً معيارياً لـ S. الخطوة 2: الإسقاط: $P_S g = UU^\top g$. الخطوة 3: التحديث الآمن: $g^\perp = g - P_S g = (I - UU^\top)g$. الخطوة 4: تحقق: $\langle g^\perp,\ s\rangle = 0$ لكل $s \in S$ ✓.

النتيجة: تحديث في المتمّم المتعامد $\Rightarrow$ لا يتداخل مع المهمة 1. الربط بالذكاء الاصطناعي: OGD و Adam-NSCL من أشهر طرق مقاومة **النسيان الكارثي** (catastrophic forgetting)؛ جوهرها الإسقاط المتعامد نفسه.

مثال (2.3-13): إزالة التحيز من التضمينات اللغوية

المعطيات: تضمين كلمة w، اتجاه التحيز g (مثل «ذكر–أنثى») بـ $\|g\| = 1$. المطلوب: إزالة مركّبة التحيز من w.

الحل: الخطوة 1: الإسقاط على اتجاه التحيز: $\text{proj}_g w = (w^\top g)\, g$. الخطوة 2: الطرح: $w^{\text{debias}} = w - (w^\top g)g$. الخطوة 3: تحقق التعامد: $(w^{\text{debias}})^\top g = w^\top g - (w^\top g)(g^\top g) = 0$ ✓. الخطوة 4: إعادة التطبيع: $w^{\text{debias}}/\|w^{\text{debias}}\|$.

النتيجة: تضمين خالٍ من مركّبة التحيز المعرَّفة. الربط بالذكاء الاصطناعي: هذه خوارزمية Bolukbasi et al. (2016) الشهيرة، Debiasing، وهي تطبيق حرفي لنظرية الإسقاط على أخلاقيات الذكاء الاصطناعي.

مثال (2.3-14): توقّع استهلاك الطاقة لمبنى

المعطيات: 12 شهراً، ميزتان: متوسط الحرارة (h) وعدد الأيام (d)، استهلاك y، أُعطي $A^\top A = \begin{bmatrix}12 & 0\\ 0 & 12\end{bmatrix}$ (ميزات متعامدة!) و $A^\top y = \begin{bmatrix}240\\ 36\end{bmatrix}$. المطلوب: المعاملات، ولماذا الحلّ أبسط هنا.

الحل: الخطوة 1: بما أن $A^\top A = 12I \Rightarrow (A^\top A)^{-1} = \frac{1}{12}I$. الخطوة 2: $\beta^\star = \frac{1}{12}\begin{bmatrix}240\\ 36\end{bmatrix} = \begin{bmatrix}20\\ 3\end{bmatrix}$. الخطوة 3: الدرس: تعامد الميزات يجعل كل معامل يُحسب مستقلاً.

النتيجة: الاستهلاك $3d + 20 =$ (بوحدات مناسبة). الربط بالذكاء الاصطناعي: هذا هو سبب شيوع **تبييض الميزات** و decorrelation قبل الانحدار: يجعل المصفوفة قطرية فيزول الترابط العددي وتتسارع كل خوارزميات التحسين.

مثال (2.3-15): كشف الشذوذ بناظم الباقي

المعطيات: نموذج الفضاء الجزئي W ببعد 3 في $\mathbb{R}^{20}$ من عيّنات سليمة، عتبة الباقي 5.0؛ عيّنة جديدة y بـ $\|y\| = 5$ و $\|P_W y\| = 4.2$. المطلوب: هل العيّنة شاذّة؟

الحل: الخطوة 1: بفيثاغورس (19.2): $\|e\|^2 = \|y\|^2 - \|P_W y\|^2 = 25 - 17.64 = 7.36$. الخطوة 2: $\|e\| = 2.71$. الخطوة 3: $2.71 > 0.5 \Longrightarrow$ شاذّة.

النتيجة: شذوذ مؤكَّد بباقي 2.71. الربط بالذكاء الاصطناعي: تقنيات detection anomaly PCA-based و detection reconstruction-error في autoencoders تعمل بهذه الآلية بالضبط: ما لا يستطيع النموذج «إعادة بنائه» هو الشاذ.

6.4.2 أخطاء شائعة

الخطأ	الصواب
عكس $A^\top A$ عند تبعية الأعمدة	استخدم المعكوس الزائف (pseudo-inverse) أو التنظيم
افتراض أن إسقاطاً على أساس غير متعامد = مجموع الإسقاطات	صحيح فقط لأساس متعامد معياري (بارسيفال)
تجاهل شرط $\perp$	بدون التعامد لا تكون النقطة هي الأقرب (14.2)
حساب $\|e\|$ كفرق الناظمين	استخدم فيثاغورس: $\|e\|^2 = \|y\|^2 - \|\hat{y}\|^2$

الأهمية: كل مرة تريد فيها «محاور مستقلة تماماً» في بياناتك — تبييض، تهيئة أوزان، إزالة تعدد خطي، حساب مستقر للمربعات الصغرى — فأنت تستخدم غرام–شميدت، حتى لو لم تكتبه بيدك.

1.5.2 الصياغة الرسمية

خوارزمية غرام–شميدت: ليكن $\{v_1, \dots, v_k\}$ مستقلاً خطياً في فضاء جداء داخلي. نُعرّف بالتدرّج:

$$w_1 = v_1, \qquad u_1 = \frac{w_1}{\|w_1\|} \tag{21.2}$$

$$w_j = v_j - \sum_{i=1}^{j-1} \langle v_j,\, u_i \rangle\, u_i, \qquad u_j = \frac{w_j}{\|w_j\|}, \quad j = 2, \dots, k \tag{22.2}$$

النتيجة — التحليل QR: لأي $A \in \mathbb{R}^{m \times n}$ $(m \geq n)$ بأعمدة مستقلة يوجد وحيداً:

$$A = Q\,R, \qquad Q^\top Q = I_n, \qquad R \text{ مثلثية عليا بقطر موجب} \tag{23.2}$$

حيث عناصر R:

$$R_{ij} = \langle v_j,\, u_i \rangle \ (i < j), \qquad R_{jj} = \|w_j\| > 0 \tag{24.2}$$

خاصية حفظ الأطوال (Isometry):

$$\forall x \in \mathbb{R}^n: \quad \|Qx\| = \|x\|, \qquad \|A\|_F = \|R\|_F \tag{25.2}$$

حلّ المربعات الصغرى بـ QR (أكثر استقراراً من المعادلات النظامية):

$$Rx^\star = Q^\top y \tag{26.2}$$

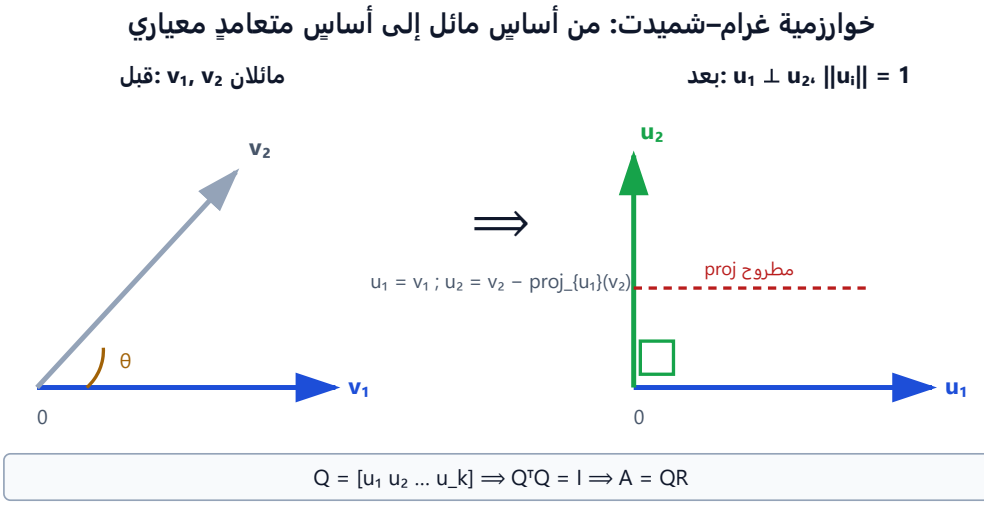
النسخة المعدّلة (Modfiied) Gram–Schmidt — المستخدمة عملياً:

$$v_j \leftarrow v_j - \langle v_j, u_i \rangle u_i \quad \text{فوراً بعد حساب كل } u_i \quad \text{لكل } i: \tag{27.2}$$

2.5.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
v_j	متجه المدخل	العمود j من A	قد يكون مائلاً/مترابطاً
w_j	المتجه المتبقّي	v_j بعد طرح إسقاطاته على السابقين	قبل التطبيع
u_j	المتجه المتعامد المعياري	$\|u_j\| = 1$، $u_j \perp u_i$	العمود j من Q
Q	مصفوفة متعامدة	$Q^\top Q = I$	أعمدة متعامدة معيارية
R	مثلثية عليا	تحمل الإحداثيات	تُحلّ بالتعويض العكسي
$R_{jj} > 0$	القطر الموجب	شرط الوحدانية لـ QR	—
$\|\cdot\|_F$	ناظم فروبنيوس	محفوظ تحت الضرب بـ Q	(25.2)
$O(mn^2)$	تكلفة غرام–شميدت	نفس تكلفة QR	—
$\kappa_2(A)$	عدد الحالة الشرطية	$\kappa_2(A) = \kappa_2(R)$؛ المعادلات النظامية تُربيعه κ^2	سبب اختيار QR

3.5.2 الشكل الهندسي



شكل ٤.٢: *
غرام–شميدت

شكل (4.2): من متجهين مائلين إلى متجهين متعامدين معياريين بطرح إسقاط v_2 على u_1.

4.5.2 البرهان

الاستقراء على j: الأساس $j=1$: $w_1 = v_1 \neq \mathbf{0}$ (لأن المجموعة مستقلة) $\Rightarrow u_1$ معرَّف و $\|u_1\| = 1$.

الخطوة: لنفترض $u_1, \dots, u_{j-1}$ متعامدة معيارية وتولّد نفس فضاء $v_1, \dots, v_{j-1}$. نُعرّف w_j بـ (22.2). نُثبت التعامد: لكل $i < j$:

$$\langle w_j,\ u_i \rangle \;=\; \langle v_j,\ u_i \rangle \;-\; \sum_{\ell<j} \langle v_j, u_\ell \rangle \underbrace{\langle u_\ell, u_i \rangle}_{=\delta_{\ell i}} \;=\; \langle v_j, u_i \rangle - \langle v_j, u_i \rangle \;=\; 0$$

ولو كان $w_j = \mathbf{0}$ لكان $v_j \in \operatorname{span}\{u_1,\dots,u_{j-1}\} = \operatorname{span}\{v_1,\dots,v_{j-1}\}$ $\Rightarrow$ تناقض مع الاستقلال $\Rightarrow w_j \neq \mathbf{0} \Rightarrow u_j$ معرَّف.

التحليل QR: من (22.2): $v_j = \sum_{i<j} \langle v_j, u_i \rangle u_i + \|w_j\| u_j = \sum_{i \le j} R_{ij} u_i$، وهو بالضبط العمود j من QR. و R مثلثية عليا لأن $R_{ij} = 0$ لـ $i > j$. ■

ملاحظة عددية مهمة:

غرام–شميدت الكلاسيكي يفقد التعامد بسبب أخطاء الفاصلة العائمة؛ النسخة المعدّلة (27.2) أفضل، وتحويلات Householder (انعكاسات) هي الأكثر استقراراً وتُستخدم في LAPACK.

5.5.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (4.2-1): غرام–شميدت على متجهين في $\mathbb{R}^2$

المعطيات: $v_1 = (3, 1)$، $v_2 = (2, 2)$. المطلوب: أساس متعامد معياري.

الحل: الخطوة 1: $u_1 = v_1/\|v_1\| = (3,1)/\sqrt{10} = (0.9487,\ 0.3162)$. الخطوة 2: $\langle v_2, u_1 \rangle = 2(0.9487) + 2(0.3162) = 1.8974 + 0.6324 = 2.5298$. الخطوة 3: $w_2 = v_2 - 2.5298\, u_1 = (2, 2) - (2.4,\ 0.8) = (-0.4,\ 1.2)$. الخطوة 4: $\|w_2\| = \sqrt{0.16 + 1.44} = \sqrt{1.6} = 1.2649 \Rightarrow u_2 = (-0.3162,\ 0.9487)$. الخطوة 5: تحقق: $\langle u_1, u_2 \rangle = -0.3 + 0.3 = 0$ ✓.

النتيجة: $\{u_1, u_2\}$ أساس متعامد معياري لـ $\mathbb{R}^2$. الربط بالذكاء الاصطناعي: هذه العملية هي نواة كل خوارزمية تبييض (whitening) وتُطبَّق على دفعات الميزات قبل التغذية للشبكة.

مثال (4.2-2): تحليل QR لمصفوفة 2×2

المعطيات: $A = \begin{bmatrix} 3 & 2 \\ 1 & 2 \end{bmatrix}$ بأعمدة v_1, v_2 من المثال السابق. المطلوب: كتابة $A = QR$ صريحة.

الحل: الخطوة 1: $Q = [u_1\ u_2] = \begin{bmatrix} 0.9487 & -0.3162 \\ 0.3162 & 0.9487 \end{bmatrix}$. الخطوة 2: $R_{11} = \|v_1\| = \sqrt{10} = 3.1623$؛ $R_{12} = \langle v_2, u_1 \rangle = 2.5298$، $R_{22} = \|w_2\| = 1.2649$. الخطوة 3: $R = \begin{bmatrix} 3.1623 & 2.5298 \\ 0 & 1.2649 \end{bmatrix}$. الخطوة 4: تحقق: العمود الأول Q: $3.1623\, u_1 = (3, 1)$ ✓.

النتيجة: تحليل QR كامل. الربط بالذكاء الاصطناعي: مكتبات مثل numpy.linalg.qr و torch.linalg.qr تُعيد هذا بالضبط، ويُستخدم لحلّ الأنظمة داخل طبقات «المربعات الصغرى القابلة للتفاضل».

مثال (2.4.3): تهيئة أوزان متعامدة في RNN

المعطيات: مصفوفة recurrent $W \in \mathbb{R}^{h \times h}$ بـ $h = 512$، نُريد $\|W\|_{\text{op}} = 1$ بالضبط. المطلوب: كيف نبنيها؟

الحل: الخطوة 1: نولّد G بمدخلات غاوسية قياسية. الخطوة 2: نُطبّق QR: $G = QR \Longrightarrow$ نأخذ $W = Q$. الخطوة 3: حينئذٍ $W^\top W = I \Longrightarrow$ كل القيم المفردة $= 1 \Longrightarrow \|W\|_{\text{op}} = 1$. الخطوة 4: يحفظ W أطوال الحالات المخفية $\Longrightarrow$ لا انفجار ولا تلاشٍ في الحالة الخطية.

النتيجة: تهيئة تحفظ الطاقة. الربط بالذكاء الاصطناعي: التهيئة المتعامدة (Orthogonal/Unitary init) هي العلاج الكلاسيكي لمشكلة التدرّجات في الشبكات المتكرّرة العميقة، وتُستخدم اليوم في RNN و ResNet وحتى في بعض طبقات الانتباه.

مثال (2.4.4): استقرار QR مقابل المعادلات النظامية

المعطيات: A عدد حالة شرطيتها $\kappa_2(A) = 10^6$. المطلوب: مقارنة فقدان الدقة بين الحلّين.

الحل: الخطوة 1: المعادلات النظامية تحسب $A^\top A \Longrightarrow \kappa_2(A^\top A) = \kappa_2(A)^2 = 10^{12}$. الخطوة 2: QR يحسب R مع $\kappa_2(R) = \kappa_2(A) = 10^6$. الخطوة 3: بدقة مضاعفة ($\varepsilon \approx 2.2 \times 10^{-16}$): الخطأ النسبي $\approx \varepsilon\kappa \Longrightarrow 2.2 \times 10^{-4}$ للمعادلات النظامية مقابل 2.2×10^{-10} لـ QR.

النتيجة: QR أدقّ بستة مراتب عشرية. الربط بالذكاء الاصطناعي: في تدريب الشبكات بميزات مترابطة (صور، تضمينات) قد ينهار الحلّ المباشر، ولهذا تستخدم المكتبات QR أو SVD أو Cholesky مع تنظيم.

مثال (2.4.5): إزالة التعدد الخطي في ميزات الانحدار

المعطيات: ثلاث ميزات: المساحة بالمتر^2، المساحة بالقدم^2، عدد الغرف. الأولى والثانية مرتبطتان خطياً تماماً. المطلوب: معالجة قبل الانحدار.

الحل: الخطوة 1: $A^\top A$ منفردة $\Longrightarrow$ المعكوس غير موجود $\Longrightarrow$ المعادلات النظامية تفشل. الخطوة 2: غرام-شميدت يكتشف ذلك: عند $j = 3$ يصبح $w_3 \approx \mathbf{0} \Longrightarrow \|w_3\| < \tau$. الخطوة 3: نُسقط العمود التابع $\Longrightarrow$ نحصل على أساس مستقل $\Longrightarrow$ نحلّ بطريقة stable.

النتيجة: ميزتان فعّاليتان بدل ثلاث. الربط بالذكاء الاصطناعي: التشخيص التلقائي بـ $\|w_j\|$ الصغير هو أساس كشف multicollinearity، وبديله الإحصائي هو عامل تضخّم التباين VIF.

مثال (2.4.6): بناء مرشحات التفافية متعامدة

المعطيات: 64 مرشحاً بحجم $3 \times 3 \times 32 \Longrightarrow$ كل مرشح متجه في $\mathbb{R}^{288}$. المطلوب: جعل المرشحات متعامدة ولماذا ذلك مفيد.

الحل: الخطوة 1: نُرصّ المرشحات كصفوف $F \in \mathbb{R}^{64\times 288}$. الخطوة 2: نُطبّق غرام-شميدت (أو تنظيمًا متعامداً أثناء التدريب) $\Longrightarrow FF^\top = I$. الخطوة 3: الفائدة: خرائط الميزات الناتجة غير مترابطة $\Longrightarrow$ معلومات غير مكرّرة. الخطوة 4: وتحسّن استقرار التدرّج لأن $\|F\|_{\text{op}} = 1$.

النتيجة: تمثيل أكثر كفاءة واستقراراً. الربط بالذكاء الاصطناعي: «التهيئة المتعامدة للمرشحات» و «Orthogonal Convolutional Neural Networks» أثبتت متانة أعلى أمام الأمثلة الخصامية.

مثال (2.4-7): حساب الحجم/المحدد بطريقة مستقرة

المعطيات: $A \in \mathbb{R}^{n\times n}$ قابلة للعكس. المطلوب: حساب $|\det A|$ بـ QR.

الحل: الخطوة 1: $\det A = \det Q \cdot \det R = (\pm 1) \cdot \prod_{j=1}^{n} R_{jj}$. الخطوة 2: إذن $|\det A| = \prod_j R_{jj}$ $= \prod_j \|w_j\|$. الخطوة 3: الحجم المتوازي السطوح = جداء أطوال المتعامدات (تفسير هندسي مباشر). الخطوة 4: ولأجل الاستقرار نحسب $\log|\det A| = \sum_j \log R_{jj}$ فنتجنّب التجاوز/التلاشي العددي.

النتيجة: حساب مستقر للمحدد عبر اللوغاريتم. الربط بالذكاء الاصطناعي: النماذج التدفقية (Normalizing Flows) تحسب بالضبط $\log|\det J|$ لتغيّر المتغيّرات؛ والـ QR/LU هي طرق حسابها.

مثال (2.4-8): خوارزمية QR للقيم الذاتية

المعطيات: مصفوفة متماثلة $S \in \mathbb{R}^{200\times 200}$، نريد قيمها الذاتية. المطلوب: مخطط الخوارزمية وسبب نجاحها.

الحل: الخطوة 1: كرّر: $S_k = Q_k R_k$ (QR) ثم $S_{k+1} = R_k Q_k$. الخطوة 2: بما أن $S_{k+1} = Q_k^\top S_k Q_k \Longrightarrow$ S_{k+1} **مشابهة** لـ $S_k \Longrightarrow$ نفس القيم الذاتية. الخطوة 3: مع التكرار يتقارب S_k إلى مصفوفة مثلثية عليا $\Longrightarrow$ القيم الذاتية على القطر. الخطوة 4: مع انزياحات (shfits) يتسارع التقارب $\Longrightarrow$ خوارزمية QR المستخدمة في LAPACK.

النتيجة: قيم ذاتية بدقة عالية. الربط بالذكاء الاصطناعي: حساب القيم الذاتية للهسيّة (Hessian) ضروري في تحليل سطح الخسارة؛ وخوارزمية QR هي العمود الفقري لـ numpy.linalg.eig.

مثال (2.4-9): محاذاة فضاءات التضمين بين لغتين (Orthogonal Procrustes)

المعطيات: تضمينات إنجليزية $X \in \mathbb{R}^{N\times d}$ وعربية $Y \in \mathbb{R}^{N\times d}$ لنفس الكلمات (قاموس ثنائي اللغة). المطلوب: مصفوفة تدوير R بأفضل محاذاة.

الحل: الخطوة 1: نُشكّل $M = X^\top Y$ ونحسب SVD: $M = U\Sigma V^\top$. الخطوة 2: الحلّ الأمثل للمسألة المتعامدة: $R^\star = UV^\top$ (مصفوفة متعامدة). الخطوة 3: نُطبّق $XR^\star$ فتقترب من Y. الخطوة 4: الخسارة الدنيا $= \|X\|_F^2 + \|Y\|_F^2 - 2\sum_i \sigma_i$.

النتيجة: محاذاة خطية متعامدة مثلى. الربط بالذكاء الاصطناعي: هذه هي خوارزمية محاذاة التضمينات عبر اللغات (MUSE, VecMap)؛ وتُستخدم لنقل النماذج بين اللغات دون بيانات متوازية.

مثال (2.4.10): تبييض الميزات (Whitening) بخطوات غرام-شميدت

المعطيات: دفعة ميزات $X \in \mathbb{R}^{1000\times 50}$ بمتوسط صفري ومصفوفة تغاير Σ. المطلوب: تحويل يجعل التغاير I.
الحل: الخطوة 1: نحلّل $\Sigma = U\Lambda U^\top$ (قيم ذاتية). الخطوة 2: التبييض: $Z = X U\Lambda^{-1/2}U^\top$ (ZCA) أو $Z = X U\Lambda^{-1/2}$ (PCA-whitening). الخطوة 3: تحقق: $\mathrm{Cov}(Z) = \Lambda^{-1/2}U^\top\Sigma U\Lambda^{-1/2} = I$ ✓. الخطوة 4: الزوايا بين الميزات بعد التبييض تصبح $90°$ $\Longrightarrow$ دلالة غرام-شميدت المعمّمة.
النتيجة: ميزات غير مترابطة بتباين 1. الربط بالذكاء الاصطناعي: التبييض يُسرّع تدريب الشبكات العميقة جداً (وهو جوهر BatchNorm و LayerNorm و ICA ويحسّن توزيع القيم المفردة.

مثال (2.4.11): بناء قاموس متعامد للضغط

المعطيات: نريد ضغط إشارات في $\mathbb{R}^{64}$ بـ 8 اتجاهات فقط. المطلوب: مقارنة قاموس عشوائي بآخر متعامد.
الحل: الخطوة 1: قاموس عشوائي $D \Longrightarrow D^\top D \neq I \Longrightarrow$ الاستعادة تحتاج عكس مصفوفة غرام (غير مستقر). الخطوة 2: قاموس متعامد $Q \Longrightarrow$ الاستعادة $= Q^\top x$ بضربة واحدة ودون عكس. الخطأ في الحالتين متقارب، لكن التكلفة: $O(k^3)$ مقابل $O(k^2)$. الخطوة 4: وعدد الحالة = 1 للمتعامد $\Longrightarrow$ لا تضخيم للضجيج.
النتيجة: المتعامد أرخص وأكثر استقراراً. الربط بالذكاء الاصطناعي: «التنظيم المتعامد» (orthogonal regularization) يُستخدم في أجهزة التشفير الذاتية لمنع انهيار القاموس، وفي ضغط النماذج.

مثال (2.4.12): فصل الإشارة عن الضجيج بأساس متعامد

المعطيات: إشارة s في فضاء جزئي S ببعد 5 من $\mathbb{R}^{100}$، قياس $y = s + n$ مع ضجيج $\|n\| = 2$ متعامد على S. المطلوب: تقدير s والخطأ المتبقي.
الحل: الخطوة 1: نبني أساساً متعامداً معيارياً $U \in \mathbb{R}^{100\times 5}$ لـ S (بغرام-شميدت). الخطوة 2: الإسقاط: $\hat{s} = UU^\top y = UU^\top(s+n) = s + UU^\top n = s$ (لأن $n \perp S$). الخطوة 3: الاستعادة تامة! الخطأ $= 0$. الخطوة 4: إن لم يكن الضجيج متعامداً تماماً: $\|خطأ\| = \|UU^\top n\| \leq \|n\| = 2$.
النتيجة: استعادة تامة للإشارة. الربط بالذكاء الاصطناعي: هذا هو مبدأ **ترشيح الضجيج بالفضاء الجزئي** (subspace filtering) المستخدم في تحسين الكلام وفي إزالة ضجيج الصور الطبية.

مثال (2.4.13): ضمان ليبشيتز = 1 بطبقة متعامدة

المعطيات: طبقة $f(x) = Wx$، نريد $\|f(x) - f(y)\| = \|x - y\|$ تماماً (حفظ المسافات). المطلوب: شرط على W.
الحل: الخطوة 1: الحفظ $\Longleftrightarrow \|Wz\|^2 = \|z\|^2$ لكل $z \Longleftrightarrow z^\top(W^\top W)z = z^\top z$. الخطوة 2: $\Longleftrightarrow W^\top W = I$ $\Longrightarrow W$ متعامدة (إن كانت مربعة). الخطوة 3: بـ QR: أي مصفوفة قابلة للعكس تُحوَّل إلى متعامدة

بأخذ عامل Q. الخطوة 4: الأثر: الشبكة 1-ليبشيتزية $\Longrightarrow$ شهادة متانة خصامية مجانية.
النتيجة: حفظ المسافات $\Longleftrightarrow$ التعامد. الربط بالذكاء الاصطناعي: «الشبكات 1-ليبشيتزية» (Parseval networks) تفرض $W^\top W = I$ أثناء التدريب فتحصل على متانة مضمونة أمام الأمثلة الخصامية.

مثال (14-4.2): بناء مساحة كامن منتظمة في VAE

المعطيات: فضاء كامن $\mathbb{R}^{32}$؛ نلاحظ أن 8 أبعاد فقط «نشطة» (posterior collapse). المطلوب: تشخيص وعلاج بغرام–شميدت.
الحل: الخطوة 1: نحسب تغاير الترميزات $\mathrm{Cov}(z)$؛ نجد رتبتها 8 $\Longrightarrow$ 24 بُعداً تابعاً. الخطوة 2: نُطبّق غرام–شميدت على اتجاهات التباين $\Longrightarrow$ نحدد الأساس الفعّال. الخطوة 3: العلاج: زيادة وزن مصطلح KL أو استخدام توزيع سابق أكثر مرونة (VampPrior). *الخطوة 4: أو إعادة تعيين الأبعاد بالأساس المتعامد الجديد $\Longrightarrow$ استخدام كامل للسعة.
النتيجة: تشخيص كمّي للانهيار. الربط بالذكاء الاصطناعي: انهيار ما بعد التوزيع (posterior collapse) من أكثر مشاكل VAE شيوعاً، ورتبة التغاير هي مقياسه الرسمي.

مثال (15-4.2): تحسين توزيع التضمينات (Isotropy)

المعطيات: 10,000 تضمين جملة؛ القيم المفردة العشر الأولى $(50,\ 10,\ 3,\ 2,\ 1.8,\ \dots) \Longrightarrow$ تباين مركّز جداً. المطلوب: قياس «التجانس الاتجاهي» (isotropy) وتحسينه.
الحل: الخطوة 1: مقياس التجانس $I = \frac{\sigma_{\min}}{\sigma_{\max}}$؛ هنا $I \approx 0.02 \Longrightarrow$ رديء. الخطوة 2: السبب: مركّبة هيمنة مشتركة بين كل الجمل (مثل طول الجملة أو تكرار كلمة شائعة). الخطوة 3: العلاج: نُطبّق غرام–شميدت لإزالة المركّبة المهيمنة الأولى: $z \leftarrow z - \langle z, u_1\rangle u_1$. الخطوة 4: بعد الإزالة: القيم المفردة $(10,\ 3,\ 2,\ \dots) \Longrightarrow I \approx 0.2 \Longrightarrow$ تحسّن $\times 10$.
النتيجة: تجانس $0.02 \longrightarrow 0.2$. الربط بالذكاء الاصطناعي: تقنية «إزالة المركّبة الرئيسية» (All-but-the-Top) حسّنت أداء تضمينات الجمل في معايير الاسترجاع الدلالي بشكل ملحوظ.

6.5.2 أخطاء شائعة

الخطأ	الصواب
استخدام غرام–شميدت الكلاسيكي في الفاصلة العائمة	استخدم النسخة المعدّلة أو Householder
افتراض Q مربّعة دائماً	Q مستطيلة $m \times n$ بـ $Q^\top Q = I_n$ فقط
تطبيق غرام–شميدت على متجهات تابعة	ينهار عند $w_j = \mathbf{0}$؛ افحص $\|w_j\|$
تفضيل المعادلات النظامية على QR	QR لا يربّع عدد الحالة $\Longrightarrow$ أدقّ

الأهمية: «كم بُعداً من المعلومات يمرّ فعلاً عبر هذه الطبقة؟» — سؤالٌ تجيب عنه الرتبة. وهي الأداة التي تكشف انهيار التمثيل، وتحدّد المعلمات الفعّالة، وتبرّر ضغط النماذج.

1.6.2 الصياغة الرسمية

النظرية الأساسية: لتكن $A : \mathbb{R}^n \to \mathbb{R}^m$ تحويلاً خطياً (أو مصفوفة $A \in \mathbb{R}^{m\times n}$):

$$\underbrace{\dim \ker(A)}_{\text{nullity العدمية}} + \underbrace{\dim \operatorname{im}(A)}_{\text{rank الرتبة}} = \dim \mathbb{R}^n = n \tag{28.2}$$

أي بصيغة مختصرة:

$$\operatorname{nullity}(A) + \operatorname{rank}(A) = n \tag{29.2}$$

حيث:

$$\ker(A) = \{x \in \mathbb{R}^n : Ax = \mathbf{0}\}, \qquad \operatorname{im}(A) = \{Ax : x \in \mathbb{R}^n\} = \operatorname{col}(A) \tag{30.2}$$

خصائص الرتبة الملازمة:

$$\operatorname{rank}(A) = \operatorname{rank}(A^\top) = \dim \operatorname{row}(A) = \dim \operatorname{col}(A) \tag{31.2}$$

$$\operatorname{rank}(A) \le \min(m, n), \qquad \operatorname{rank}(A^\top A) = \operatorname{rank}(AA^\top) = \operatorname{rank}(A) \tag{32.2}$$

متراجحة سيلفستر للرتبة:

$$\operatorname{rank}(A) + \operatorname{rank}(B) - n \le \operatorname{rank}(AB) \le \min\big(\operatorname{rank}(A), \operatorname{rank}(B)\big) \tag{33.2}$$

$$\operatorname{rank}(A + B) \le \operatorname{rank}(A) + \operatorname{rank}(B) \tag{34.2}$$

حالات النظام $Ax = b$:

$$\operatorname{rank}(A) = \operatorname{rank}([A \mid b]) = n \iff \text{حلّ وحيد} \tag{35.2}$$

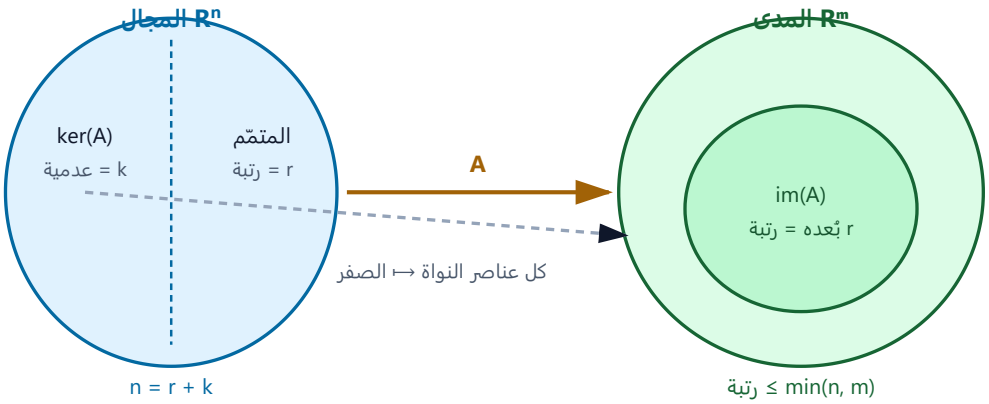
$$\operatorname{rank}(A) = \operatorname{rank}([A \mid b]) < n \iff \text{حلول لانهائية (ببعد } n - \operatorname{rank}(A)) \tag{36.2}$$

$$\operatorname{rank}(A) < \operatorname{rank}([A \mid b]) \iff \text{لا حلّ} \Rightarrow \text{نلجأ للمربعات الصغرى} \tag{37.2}$$

2.6.2 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
$\ker(A)$	النواة (فضاء العدم)	المدخلات التي تُصبح صفراً	ما «يُفقد» من المعلومات
$\operatorname{im}(A)$	الصورة (المدى)	كل المخرجات الممكنة	فضاء التمثيل
$\operatorname{rank}(A)$	الرتبة	عدد الأعمدة/الصفوف المستقلة	np.linalg.matrix_rank
$\operatorname{nullity}(A)$	العدمية	$n - \operatorname{rank}(A)$	درجات الحرية المفقودة
$\operatorname{col}(A)$	فضاء الأعمدة	توليده = الصورة	—
$\operatorname{row}(A)$	فضاء الصفوف	بُعده = الرتبة	(31.2)
$[A \mid b]$	المصفوفة المُلحَقة	A مع عمود b	فحص وجود الحلّ
n	بُعد المجال	عدد الميزات/المعلمات	—
m	بُعد المدى	عدد المخرجات	—
$\operatorname{rank}_\varepsilon$	الرتبة العددية	عدد القيم المفردة $> \varepsilon$	الرتبة العملية في الحاسوب

نظرية الرتبة والعدمية: dim ker(A) + dim im(A) = n



شكل (2.5): ما «يُفقد» في النواة يقابله بالضبط ما «يبقى» في الصورة

شكل ٥.٢: *
الرتبة والعدمية

3.6.2 الشكل الهندسي

شكل (5.2): المجال $\mathbb{R}^n$ ينقسم إلى نواة (بُعد k) ومتمّم (بُعد r)؛ والمتمّم يُنقل وفاءً إلى الصورة.

4.6.2 البرهان

ليكن $\{u_1, \dots, u_k\}$ أساساً لـ $\ker(A)$. نُكمّله (بلامّة التبادل 3.2 يمكن التكميل) إلى أساس للفضاء كله:

$$\mathcal{B} = \{u_1, \dots, u_k,\ v_1, \dots, v_r\}, \qquad k + r = n$$

ندّعي أن $\{Av_1, \dots, Av_r\}$ أساسٌ لـ $\operatorname{im}(A)$:

- **التوليد:** كل $y = Ax$ حيث $x = \sum \alpha_i u_i + \sum \beta_j v_j \Longrightarrow Ax = \sum \alpha_i \underbrace{Au_i}_{=0} + \sum \beta_j Av_j$ في $\operatorname{span}\{Av_j\}$.
- **الاستقلال:** لو $\sum \beta_j Av_j = 0$ فـ $A(\sum \beta_j v_j) = 0 \Longrightarrow \sum \beta_j v_j \in \ker(A)$ $\Longrightarrow$ هو تركيبة من $\{u_i\}$ $\Longrightarrow$ بالاستقلال كل $\beta_j = 0$.

إذن $\dim \operatorname{im}(A) = r$ و $\dim \ker(A) = k$ و $r + k = n$ $\Longrightarrow$ (28.2). $\blacksquare$

5.6.2 أمثلة واقعية محلولة (15 مثالاً)

مثال (5.2-1): رتبة مصفوفة أوزان طبقة عصبية

المعطيات: طبقة بـ 256 مدخلاً و 128 مخرجاً، مصفوفة الأوزان $W \in \mathbb{R}^{128 \times 256}$، الرتبة المقاسة 90. المطلوب: كم خلية مخرجة «فعّالة»؟ وكم بُعداً من المدخل مهمل؟

الحل: الخطوة 1: $\operatorname{rank}(W) = 90 \implies$ فضاء المخرجات الفعّال بُعده 90 من 128. الخطوة 2: العدمية $= 256 - 166 = 90 \implies 166$ بُعداً من المدخل لا تؤثّر في المخرج. الخطوة 3: نسبة الهدر $166/256 = 64.8\%$.

النتيجة: 38 خلية مخرجة زائدة، و 166 بُعد مدخل مُهمَلة. الربط بالذكاء الاصطناعي: قياس الرتبة الفعّالة أداة تشخيص قوية: رتبة منخفضة $\implies$ إمكانية تقليم (pruning) الطبقة دون فقدان يُذكر.

مثال (2-5.2): LoRA وتحديد الرتبة

المعطيات: $W_0 \in \mathbb{R}^{4096\times 4096}$، التحديث $\Delta W = BA$ برتبة $r = 8$. المطلوب: بُعد صورة التحديث والعدمية.

الحل: الخطوة 1: $\operatorname{rank}(\Delta W) \le \min(\operatorname{rank} B,\ \operatorname{rank} A) \le 8$ بـ (33.2). الخطوة 2: صورة التحديث بُعدها ≤ 8 من أصل 4096. الخطوة 3: العدمية $4096 - 8 = 4088 \implies$ كل اتجاه خارج فضاء بُعده 8 يمرّ دون تغيير.

النتيجة: 99.8% من الاتجاهات «غير قابلة للتحديث» بهذه الطريقة. الربط بالذكاء الاصطناعي: هذا قيدٌ متعمَّد: الضبط الدقيق يحتاج مرونة محدودة لتجنّب النسيان الكارثي؛ ولذلك نجحت LoRA عملياً برتب 4–64 فقط.

مثال (3-5.2): أثر Dropout على الرتبة الفعّالة

المعطيات: مصفوفة تفعيلات $H \in \mathbb{R}^{512\times 128}$ (عيّنات × خلايا) برتبة 128، نُطبّق dropout بمعدل $p = 0.5$.

المطلوب: ما أثر ذلك على الرتبة؟

الحل: الخطوة 1: كل خلية تُصفَّر باحتمال 0.5 $\implies$ الرتبة المتوقّعة تنخفض لكن لا تصل إلى 64 بالضرورة. الخطوة 2: الرتبة بعد التصفير $\le \min(512،$ عدد الخلايا الناجية$) \approx 64$. الخطوة 3: لكن القياس التجريبي يظهر رتبة فعّالة أعلى ($\approx$ 90–110) لأن التصفير لا يخلق تبعية كاملة. الخطوة 4: المعنى: dropout يمنع الشبكة من الاعتماد على تركيبات خطية محدّدة $\implies$ تنظيم ضمني.

النتيجة: انخفاض الرتبة الفعّالة = تنظيم. الربط بالذكاء الاصطناعي: Dropout يمكن فهمه كـ «تنظيم على رتبة التمثيل»، وهو يمنع التخصّص المفرط لأعمدة محدّدة.

مثال (4-5.2): كشف الميزات المتكرّرة في جدول

المعطيات: مصفوفة ميزات $X \in \mathbb{R}^{1000\times 12}$، الرتبة المقاسة 10. المطلوب: كم علاقة خطية مخفية بين الميزات؟

الحل: الخطوة 1: العدمية $12 - 10 = 2 \implies$ بُعد فضاء العلاقات $= 2$. الخطوة 2: إذن توجد معادلتان خطيتان مستقلتان بين الأعمدة (مثل: «المساحة بالمتر^2 = 10.76 × المساحة بالقدم^2» و «المجموع = 1»). الخطوة 3: يجب إسقاط عمودين قبل الانحدار.

النتيجة: علاقتان خطيتان خفيتان يجب إزالتهما. الربط بالذكاء الاصطناعي: الرتبة العددية تُحسب بعدد القيم المفردة التي تتجاوز عتبة $\varepsilon = \sigma_1 \cdot 10^{-12}$، وهي طريقة عملية لاكتشاف التعدد الخطي تلقائياً.

مثال (2.5-5): عدد المعلمات القابلة للتحديد

المعطيات: انحدار خطي بـ $p = 200$ ميزة و $n = 150$ عيّنة. المطلوب: هل يمكن تحديد المعلمات الـ 200؟

الحل: الخطوة 1: $X \in \mathbb{R}^{150\times 200} \Rightarrow \text{rank}(X) \leq \min(150, 200) = 150$. الخطوة 2: العدمية $= 200 - 150 = 50$ فضاء حلول للمعادلات المتجانسة بُعده 50 على الأقل. الخطوة 3: إذن توجد عائلات لانهائية من الأوزان تعطي نفس المخرجات $\Rightarrow X^\top X$ منفردة.

النتيجة: غير قابلة للتحديد $\Rightarrow$ يلزم تنظيم Ridge ($X^\top X + \lambda I$ يجعلها قابلة للعكس). الربط بالذكاء الاصطناعي: إضافة λI ترفع كل القيم الذاتية بمقدار $\lambda \Rightarrow$ المصفوفة موجبة التحديد $\Rightarrow$ حلّ وحيد، وهذا هو التبرير الرياضي لتنظيم L_2.

مثال (2.5-6): انهيار الرتبة في الانتباه (Rank Collapse)

المعطيات: شبكة محوّل بـ $L = 24$ طبقة، مصفوفة الانتباه A صفوفها توزيعات احتمالية، نلاحظ أن مخرجات الطبقات تتقارب. المطلوب: تفسير ذلك بالرتبة.

الحل: الخطوة 1: التحديث المتبقّي: $X^{(\ell+1)} = X^{(\ell)} + AX^{(\ell)}W$. الخطوة 2: بدون التوصيل المتبقّي والتطبيع، تكرار ضرب المصفوفات ذات القيمة المفردة المهيمنة 1 يجعل A^L تتقارب إلى مصفوفة رتبتها 1. الخطوة 3: $\Rightarrow$ كل الرموز (tokens) تحصل على التمثيل ذاته $\Rightarrow$ انهيار الرتبة إلى 1. الخطوة 4: العلاج: التوصيلات المتبقّية تضيف I فتبقي القيم المفردة قريبة من 1 ولا تنهار.

النتيجة: الرتبة تنهار من d إلى 1 مع العمق. الربط بالذكاء الاصطناعي: ظاهرة collapse rank موثّقة نظرياً، وهي تفسّر لماذا المحوّلات العميقة جداً تحتاج تطبيعاً طبقياً وتوصيلات متبقّية لتعمل.

مثال (2.5-7): رتبة مصفوفة النواة (Kernel Matrix)

المعطيات: 500 عيّنة، نواة غاوسية $K_{ij} = \exp(-\|x_i - x_j\|^2/2\sigma^2)$ مع $\sigma = 0.1$. المطلوب: هل K قابلة للعكس؟ وماذا يعني ذلك؟

الحل: الخطوة 1: نظرياً K متماثلة موجبة التحديد $\Rightarrow$ رتبتها 500. الخطوة 2: عملياً القيم الذاتية تتلاشى أُسّياً $\Rightarrow$ الرتبة العددية (بعتبة 10^{-12}) قد تكون 60 فقط. الخطوة 3: $\Rightarrow$ عكس K غير مستقر $\Rightarrow$ نضيف تنظيم $K + \lambda I$ (كما في Ridge Kernel Regression).

النتيجة: رتبة عددية 60 من 500 $\Rightarrow$ تنظيم إلزامي. الربط بالذكاء الاصطناعي: انهيار طيف النواة هو سبب الحاجة إلى تنظيم في كل طرق النواة، وهو أيضاً ما يفسّر سلوك «النواة العصبية» (NTK) في الشبكات العريضة (الفصل 40).

مثال (2.5-8): رتبة مصفوفة البيانات وعدد العيّنات المطلوب

المعطيات: بيانات صور في $\mathbb{R}^{784}$، الرتبة المقاسة لمصفوفة العيّنات (10,000 عيّنة) هي 784. المطلوب: كم عيّنة نحتاج على الأقل لضمان رتبة كاملة؟

الحل: الخطوة 1: $\text{rank}(X) \leq \min(N, 784) \implies$ نحتاج $N \geq 784$. الخطوة 2: لكن الرتبة الكاملة عددية تتطلّب استقلالاً شبه تام $\implies$ عملياً $N \gg 784$. الخطوة 3: الرتبة 784 المحقّقة $\implies$ البيانات تملأ الفضاء المحيط (لا متعدّد منخفض البعد) $\implies$ قد يدلّ على ضجيج عالٍ.

النتيجة: 784 على الأقل، عملياً آلاف. الربط بالذكاء الاصطناعي: الرتبة أداة لتقدير البعد الجوهري لمتعدّد البيانات، إن كانت الرتبة $\approx$ البعد المحيط فالمتعدّد «ممتلئ» ولا فائدة من تقليل الأبعاد.

مثال (2.5-9): التضمين العواملي في التوصية (Matrix Factorization)

المعطيات: مصفوفة تفاعلات المستخدم-العنصر $R \in \mathbb{R}^{10^6 \times 10^5}$؛ نُقرّبها برتبة $k = 50$: $R \approx UV^\top$ مع $U \in \mathbb{R}^{10^6 \times 50}$. المطلوب: عدد المعلمات ونسبة الضغط.

الحل: الخطوة 1: المعلمات الأصلية (الافتراضية) $= 10^6 \times 10^5 = 10^{11}$. الخطوة 2: المعلمات بعد التحليل $= 50(10^6 + 10^5) = 5.5 \times 10^7$. الخطوة 3: النسبة $5.5 \times 10^7 / 10^{11} = 5.5 \times 10^{-4} \implies$ ضغط $\times 1818$. الخطوة 4: العدمية $10^5 - 50 =$ بالنسبة لفضاء العناصر.

النتيجة: ضغط بأكثر من 1800 مرة. الربط بالذكاء الاصطناعي: هذا هو جوهر أنظمة التوصية الكلاسيكية (Netflix Prize)، والفرضية: التفضيلات تتولّد من عدد قليل من «العوامل الكامنة» = رتبة منخفضة.

مثال (2.5-10): قياس أثر التقليم على رتبة الأوزان

المعطيات: طبقة $W \in \mathbb{R}^{1024 \times 1024}$، الرتبة قبل التقليم 900، بعد تقليم 80% من الأوزان الرتبة 780. المطلوب: تقييم الفقدان البنيوي.

الحل: الخطوة 1: فقدان الرتبة $= 900 - 780 = 120 \implies 13\%$ من سعة التمثيل. الخطوة 2: فقدان المعلمات $= 80\%$. الخطوة 3: الكفاءة: فقدنا 80% من الذاكرة مقابل 13% من الرتبة $\implies$ صفقة ممتازة. الخطوة 4: الحدّ: الرتبة بعد التقليم $\leq 780 \implies$ لا يمكن للنموذج أن يمثّل أكثر من 780 بُعداً مستقلاً.

النتيجة: مقايضة 80%↔13% ممتازة. الربط بالذكاء الاصطناعي: **درس:** التقليم يدمّر المعلمات أسرع بكثير مما يدمّر الرتبة، ولهذا تنجح طرق ضغط النماذج إلى هذا الحد.

مثال (2.5-11): عامل تضخّم التباين (VIF) لاكتشاف التبعية

المعطيات: ميزة x_j مفسَّرة بباقي الميزات بمعامل تحديد $R_j^2 = 0.98$. المطلوب: حساب VIF وتفسيره بالرتبة.

الحل: الخطوة 1: $\text{VIF}_j = \frac{1}{1-R_j^2} = \frac{1}{0.02} = 50$. الخطوة 2: $\text{VIF} > 10 \implies$ تعدد خطي شديد. الخطوة 3: التفسير بالرتبة: x_j قريبة من فضاء الأعمدة للباقي $\implies$ الرتبة العددية لـ X أقل من عدد الأعمدة.

النتيجة: تعدد خطي حادّ، يجب إسقاط الميزة أو دمجها. الربط بالذكاء الاصطناعي: VIF هو «مقياس بعد المسافة عن الفضاء الجزئي»، وهو تطبيق مباشر لمفهوم الاستقلال الخطي على تشخيص النماذج.

مثال (2.5.12): درجات الحرية الفعّالة في Ridge

المعطيات: انحدار Ridge على $X \in \mathbb{R}^{100\times 50}$، القيم الذاتية لـ $X^\top X$: $(100, 64, 25, \dots)$، $\lambda = 4$. المطلوب: حساب درجات الحرية الفعّالة.

الحل: الخطوة 1: مؤثّر القبعة $H_\lambda = X(X^\top X + \lambda I)^{-1}X^\top$. الخطوة 2: درجات الحرية $= \operatorname{tr}(H_\lambda) = \sum_i \frac{d_i}{d_i+\lambda}$ حيث d_i قيم $X^\top X$ الذاتية. الخطوة 3: للقيم المعطاة: $\frac{100}{104}+\frac{64}{68}+\frac{25}{29}+\cdots \approx 0.962+0.941+0.862+\cdots$. الخطوة 4: المجموع ≈ 40 (بدل 50 بدون تنظيم).

النتيجة: 40 درجة حرية فعّالة بدل 50. الربط بالذكاء الاصطناعي: $\operatorname{tr}(H_\lambda)$ هو مقياس «تعقيد النموذج الفعّال»؛ ويُستخدم في معايير AIC/BIC لاختيار النماذج.

مثال (2.5.13): معايرة كاميرا كحلّ نظام

المعطيات: معايرة كاميرا تعطي نظاماً $Ax = b$ بـ $A \in \mathbb{R}^{30\times 24}$ (30 معادلة من نقاط مرجعية، 24 معلمة مجهولة). المطلوب: هل الحلّ وحيد؟

الحل: الخطوة 1: نحتاج $\operatorname{rank}(A) = 24$ (= عدد المجهولات). الخطوة 2: $\operatorname{rank}(A) \le \min(30, 24) = 24$ $\Longrightarrow$ ممكن إن كانت النقاط في وضع عام. الخطوة 3: إن كانت كل النقاط على مستوٍ واحد $\Longrightarrow$ الرتبة تنخفض $\Longrightarrow$ عدمية > 0 $\Longrightarrow$ حلول لانهائية. الخطوة 4: عملياً نحلّ بالمربعات الصغرى عبر SVD لأن $\operatorname{rank}(A) < \operatorname{rank}([A \mid b])$ دائماً بسبب الضجيج (37.2).

النتيجة: الحلّ وحيد في الوضع العام، عملياً نستخدم المربعات الصغرى. الربط بالذكاء الاصطناعي: معايرة المستشعرات في الروبوتات والقيادة الذاتية كلها مسائل مربعات صغرى، ونظرية الرتبة تحدّد متى تكون المسألة «محدَّدة جيداً».

مثال (2.5.14): مصفوفة لابلاس وعدد المكوّنات المتصلة

المعطيات: رسم بياني بـ 100 عقدة، مصفوفة لابلاس $L = D - A$، الرتبة 97. المطلوب: كم مكوّناً متصلاً في الرسم؟

الحل: الخطوة 1: نظرية: $\dim\ker(L) =$ عدد المكوّنات المتصلة. الخطوة 2: العدمية $= 100 - 97 = 3$. الخطوة 3: $\Longrightarrow$ 3 مكوّنات متصلة. الخطوة 4: النواة مولّدة بمؤشّرات المكوّنات (متجهات ثابتة على كل مكوّن).

النتيجة: 3 مكوّنات متصلة. الربط بالذكاء الاصطناعي: هذه الحقيقة أساسية في الشبكات العصبية البيانية (GNN): الرتبة/العدمية تحدّد «التجاويف» وتُستخدم في التجميع الطيفي (spectral clustering) عبر القيم الذاتية الصغيرة.

مثال (2.5.15): قياس أثر التكميم على الرتبة الفعّالة

المعطيات: مصفوفة أوزان W برتبة عددية 100 (بعتبة 10^{-6})، بعد تكميم int8 تصبح الرتبة العددية 42. المطلوب:

تفسير وعلاج.

الحل: الخطوة 1: التكميم يضيف خطأً $\|E\|_F \approx 0.01\|W\|_F$. الخطوة 2: كل القيم المفردة التي كانت $\|E\|_2 <$ تُغرق في الضجيج $\Longrightarrow$ تختفي من الرتبة العددية. الخطوة 3: فقدنا 58 بُعداً تمثيلياً $\Longrightarrow$ انخفاض الدقة المتوقّع. الخطوة 4: العلاج: تكميم بوعي القيم المفردة (SVD-aware) أو per-channel quantization لتقليل $\|E\|$.

النتيجة: الرتبة الفعّالة مؤشر حسّاس لجودة التكميم. الربط بالذكاء الاصطناعي: هذا يفسّر لماذا تُحافظ طرق التكميم المتقدّمة (GPTQ, AWQ) على المكوّنات الطيفية المهيمنة: الرتبة الفعّالة أهم من متوسط الخطأ التربيعي.

6.6.2 أخطاء شائعة

الخطأ	الصواب
حساب الرتبة بالقيم الذاتية بدل المفردة للرتبة العددية	الرتبة العددية تحتاج قيماً مفردة (موجبة دائماً)
افتراض $\operatorname{rank}(AB) = \min(\operatorname{rank} A, \operatorname{rank} B)$	متراجحة فقط (33.2) ليست مساواة
تجاهل العتبة عند القياس الحاسوبي	الرتبة «الدقيقة» حسّاسة للضجيج؛ استخدم $\operatorname{rank}_\varepsilon$
ظنّ أن $A^\top A$ قابلة للعكس دائماً	قابلة للعكس $\Longleftrightarrow \operatorname{rank}(A) = n$

المستوى (أ) — تطبيق مباشر

١. بيّن أن $\{v_1, v_2\}$ بـ $v_1 = (1, 2)$، $v_2 = (2, 4)$ تابعة خطياً.

٢. أوجد بُعد $\operatorname{span}\{(1, 0, 0), (0, 1, 0), (1, 1, 0)\}$.

٣. احسب $\cos\theta$ بين $u = (1, 2, 3)$ و $v = (3, 2, 1)$، وتحقّق من (8.2).

٤. أوجد إسقاط $y = (3, 4)$ على $\operatorname{span}\{(1, 0)\}$.

٥. طبّق غرام–شميدت على $v_1 = (1, 1, 0)$، $v_2 = (1, 0, 1)$.

٦. احسب رتبة وعدمية $A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$.

٧. احسب إسقاط $y = (1, 1, 1)$ على المستوي $x_1 + x_2 + x_3 = 0$.

٨. أثبت أن $|\cos\theta| \le 1$ يتبع مباشرة من (8.2).

٩. بيّن أن $\operatorname{rank}(A^\top A) = \operatorname{rank}(A)$ باستخدام النواة.

١٠. حلّ نظام المربعات الصغرى: $A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}$، $y = (1, 2, 2)^\top$.

المستوى (ب) — تركيب

١. ليكن $U = \{(x, y, 0)\}$ و $W = \{(0, y, z)\}$ في $\mathbb{R}^3$؛ احسب $\dim(U + W)$ و $\dim(U \cap W)$ وتحقّق من (5.2).

٢. أثبت أن $\|u + v\|^2 + \|u - v\|^2 = 2\|u\|^2 + 2\|v\|^2$ (متطابقة متوازي الأضلاع).

٣. أثبت أن إسقاطاً متعامداً P يحقّق $P^2 = P$ و $P^\top = P$، والعكس صحيح.

٤. أثبت أن $I - P_W$ هو الإسقاط على $W^\perp$.

٥. بيّن أن أعمدة Q من تحليل QR تحقّق $Q^\top Q = I$ إذا كانت Q مستطيلة؛ متى تصبح $Q Q^\top = I$؟

٦. أثبت أن $\operatorname{rank}(A+B) \le \operatorname{rank}(A) + \operatorname{rank}(B)$.

٧. في $\mathbb{R}^d$، برهن أن أقصى عدد متجهات بزاوية زوجية $\ge 60^\circ$ هو 2^d تقريباً (استخدم كوشي–شفارتس).

٨. أثبت أن $\|P_W y\| \le \|y\|$ (الإسقاط لا يكبّر).

٩. ليكن $A \in \mathbb{R}^{m \times n}$ بـ $m < n$؛ برهن أن $Ax = 0$ له حلٌّ غير صفري، وفسّر ذلك في سياق «المعلمات الزائدة».

١٠. أوجد أفضل تقريب من الدرجة الأولى للنقاط $(0,1), (1,0), (2,2)$ باستخدام الإسقاط.

المستوى (ج) — تحدٍّ

١. أثبت متراجحة بيسل (20.2) ثم متطابقة بارسيفال باستخدام نظرية الإسقاط.

٢. برهن مبرهنة Johnson–Lindenstrauss في صيغتها الأساسية باستخدام كوشي–شفارتس على الإسقاط العشوائي.

٣. أثبت أن $\operatorname{rank}(A) = \operatorname{rank}(A^\top A)$ باستخدام $\ker(A^\top A) = \ker(A)$.

٤. ليكن W مصفوفة أوزان متعامدة ($W^\top W = I$)؛ أثبت أن التدرّج على W في الشبكة العميقة يحفظ الناظم.

٥. برهن أن أفضل تقريب منخفض الرتبة لمصفوفة يُعطى باقتطاع SVD (مبرهنة Eckart–Young — مخطط البرهان فقط (يُفصَّل في الفصل 4).

٦. أثبت أن تقارب خوارزمية QR للقيم الذاتية يحفظ الطيف (مشابهة).

٧. بيّن أن فضاء متعددات الحدود من الدرجة $\le k$ على $[0,1]$ فضاءٌ متجهي بُعده $k+1$، وابحث أساساً متعامداً (متعددات ليجاندر).

٨. برهن أن $\dim \operatorname{span} \le$ عدد المتجهات، وأن التساوي $\iff$ الاستقلال.

٩. في شبكة بـ L طبقة وروابط متبقّية: برهن أن مسار التدرّج يمرّ عبر فضاء بُعده $\ge \dim \operatorname{im}(\prod J_\ell)$، وناقش أثر ذلك على التلاشي.

١٠. صمّم مقياساً عملياً لـ «الرتبة الفعّالة» لمصفوفة تمثيلات في شبكة عصبية، وبرر اختيار العتبة ε باستخدام تحليل الضجيج.

إجابات مختصرة

#	الإجابة
1	$v_2 = 2v_1$
2	2 (الثالث = مجموع الأولين)
3	$\langle u, v\rangle = 10$، $\|u\| = \|v\| = \sqrt{14} \Rightarrow \cos\theta = 10/14 = 0.714$
4	$(3, 0)$
5	$u_1 = \frac{1}{\sqrt{2}}(1,1,0)$، $w_2 = v_2 - \frac{1}{2}v_1$... بعد الحساب: $u_2 = \frac{1}{\sqrt{6}}(1,-1,2)$
6	رتبة 1، عدمية 1
7	$\hat{y} = y - \frac{y^\top \mathbf{1}}{3}\mathbf{1} = (0,0,0)$
8	بالتعريف (9.2) مع (8.2)
9	(29.2) $\Rightarrow$ نفس العدمية $\Rightarrow \ker(A^\top A) = \ker(A)$
10	$\beta = (2/3,\ 1/2)$
11	✓ $2 + 2 - 1 = 3 \Rightarrow \dim(U \cap W) = 1$، $\dim(U + W) = 3$
12	بسط الجداءات الداخلية
13	من (18.2)
14	تحقق شرط التعامد (14.2)
15	إذا كانت Q مربّعة $(m = n)$
16	$\operatorname{col}(A + B) \subseteq \operatorname{col}(A) + \operatorname{col}(B)$ مع (5.2)
17	بحجّة حجم الكرات على الكرة
18	بفيثاغورس (19.2)
19	$= n - \text{rank} \geq n - m > 0$ عدمية
20	$\hat{y} = 0.5 + 0.5t$
21	الإسقاط على $\operatorname{span}\{u_1, \ldots, u_k\}$ ثم فيثاغورس
22	تركيز القيم المفردة للإسقاط العشوائي
23	$x^\top A^\top A x = \|Ax\|^2 = 0 \iff Ax = 0$
24	$\|Qg\| = \|g\|$
25	بواسطة متراجحة Weyl للقيم المفردة
26	متشابهة $\Rightarrow S_{k+1} = Q_k^\top S_k Q_k$
27	أساس؛ ليجاندر بالتعامد على $[0,1]$ $\{1, t, \ldots, t^k\}$
28	مباشر من تعريف التوليد والاستقلال
29	رتبة جداء اليعقوبيات تحدّد «عرض عنق الزجاجة»
30	$\varepsilon = c \cdot \sigma_1 \cdot \sqrt{\text{تباين الضجيج}}$

النظرية	الصيغة المحورية	متى تستخدمها
شتاينيتز/ثبات البُعد	$\|\mathcal{B}_1\| = \|\mathcal{B}_2\| = \dim V$، $k \leq m$	حساب أبعاد الفضاءات واتحادها وتقاطعها
كوشي–شفارتس/المثلث	$\|\langle u, v\rangle\| \leq \|u\|\|v\|$	حدود التشابه، ليبشيتز، استقرار التدرّج
الإسقاط المتعامد	$\hat{y} = A(A^\top A)^{-1}A^\top y$	الانحدار، PCA، الضغط، إزالة التحيز
غرام–شميدت/QR	$A = QR$، $Q^\top Q = I$	تبييض، تهيئة متعامدة، حلول مستقرة
الرتبة والعدمية	$\text{rank} + \text{nullity} = n$	تشخيص انهيار التمثيل، المعلمات الفعّالة

الخيط الناظم: كل نظرية في هذا الفصل تجيب عن سؤال واحد: **كم بُعداً من المعلومات يمرّ فعلاً، وأين يذهب الباقي؟** — الإجابة تحدّد سعة النموذج واستقراره وقابليته للضغط.

الرمز	المعنى	القسم
V, $\mathbb{F}$, $\mathbf{0}$, $-v$	فضاء متجهي، حقل، صفر، معاكس جمعي	1.2
span, $\leq$, $\oplus$, dim	توليد، فضاء جزئي، جمع مباشر، بُعد	1.2
$\langle u, v\rangle$, $\|u\|$, θ	جداء داخلي، ناظم، زاوية	3.2
$\cos\theta$, $\perp$, $\hat{y}$, e	تشابه، تعامد، إسقاط، باقي	4.2–3.2
P_W, $A^\top A$, $x^\star$	مؤثّر إسقاط، مصفوفة غرام، حلّ أمثل	4.2
w_j, u_j, Q, R	متبقٍّ غرام–شميدت، متعامد معياري، عاملان	5.2
ker, im, rank, nullity	نواة، صورة، رتبة، عدمية	6.2
$\|A\|_{\text{op}}$, $\|A\|_F$, σ_1	ناظم تشغيلي، فروبنيوس، قيمة مفردة عليا	3.2
$\kappa_2(A)$, rank_ε	عدد الحالة، رتبة عددية	6.2–5.2
col, row, $[A \mid b]$	فضاء أعمدة، صفوف، مصفوفة مُلحَقة	6.2

١. **Strang** — *Introduction to Linear Algebra*, 4th ed., Ch. 1–4 (الفضاءات المتجهة، الإسقاط، التحليلات).

٢. **Axler** — *Linear Algebra Done Right*, 3rd ed., Ch. 1–6 (بُنى الفضاءات والتعامد بلا محدّدات).

٣. **Bau & Trefethen** — *Algebra Linear Numerical*, Lecture 7–11 (QR، SVD، الاستقرار العددي).

٤. **Loan Van & Golub** — *Computations Matrix* (المرجع الأمّ للحسابات الماتريسية).

٥. **Courville Bengio, Goodfellow,** — *Learning Deep*, Ch. 2 (الجبر الخطي التطبيقي للتعلّم العميق).

٦. **Bolukbasi et al. (2016)** — *Man is to Computer Programmer as Woman is to Homemaker?* تطبيق الإسقاط على إزالة التحيز *Embeddings Word Debiasing*.

الفصل القادم: المصفوفات والتحويلات الخطية — حيث تتحول الأوزان إلى «حركات هندسية» ونتعلّم قراءة ما تفعله كل طبقة بالبيانات.

المصفوفات والتحويلات الخطية

الشعار: «المصفوفة ليست جدول أرقام؛ إنها **حركة**. والطبقة العصبية ليست مجموعة أوزان؛ إنها تحويلٌ هندسي متبوعٌ بانثناء. افهم الحركة تفهم النموذج.»

أهداف الفصل

بنهاية هذا الفصل يكون القارئ قادراً على:

١. تمثيل أي تحويل خطي بمصفوفة، وتغيير الأساس بكفاءة.

٢. استخدام **المحدّد** كمقياس لتضخّم الحجم ولاختبار قابلية العكس، وفهم دوره في النماذج التوليدية.

٣. استخدام **الآثر** ودوريّته لتبسيط حسابات الخسائر والتدرّجات الماتريسية.

٤. تطبيق **متطابقة وودبري** لتحديث المعكوسات بتحديثات منخفضة الرتبة (GP، RLS، كالمان).

٥. تفكيك أي تحويل خطي بـ **التفكك القطبي** إلى «شكل» (تدوير) و«حجم» (تمدد).

المتطلبات المسبقة

الفصلان الأول والثاني (المنطق والمجموعات · الفضاءات المتجهة والإسقاط).

خريطة الفصل

القسم	النظرية/القانون	عدد الأمثلة المحلولة
1.3	التمثيل الماتريسي للتحويل الخطي وتغيير الأساس	15
2.3	**نظرية المحدّد وخصائصه**	15
3.3	**نظرية الآثر ودوريّته**	15
4.3	**المعكوس ومتطابقة وودبري**	15
5.3	**التفكك القطبي والتصنيف الهندسي**	15
6.3	تمارين غنية + ملخص + فهرس رموز	30 تمريناً

المصطلحات الإنجليزية المقابلة

· Jacobian · Determinant · Similarity · Basis of Change · Representation Matrix · Map Linear · Inversion Block · Sherman–Morrison–Woodbury · Inverse Matrix · Property Cyclic · Trace · Product Kronecker · Factor Semidefinite Positive · Factor Orthogonal · Decomposition Polar Vectorization

1.1.3 الصياغة الرسمية

التحويل الخطي: دالة $T : V \to W$ تحفظ التركيبات الخطية:

$$T(\alpha u + \beta v) \;=\; \alpha\, T(u) \;+\; \beta\, T(v) \tag{1.3}$$

التمثيل الماتريسي: ليكن $\mathcal{B} = \{b_1, \ldots, b_n\}$ أساساً لـ V و $\mathcal{C}$ أساساً لـ W. تُعرَّف مصفوفة التحويل:

$$A \;=\; [T]_{\mathcal{C} \leftarrow \mathcal{B}}, \qquad A_{:,\,j} \;=\; [\,T(b_j)\,]_{\mathcal{C}} \tag{2.3}$$

أي: **العمود j من A هو صورة المتجه الأساس b_j مكتوبةً في أساس المدى.**
قاعدة العمل:

$$[\,T(v)\,]_{\mathcal{C}} \;=\; A\,[\,v\,]_{\mathcal{B}} \tag{3.3}$$

التركيب = ضرب المصفوفات:

$$[\,S \circ T\,] \;=\; [S]\,[T], \qquad (S \circ T)(v) = S(T(v)) \tag{4.3}$$

تغيير الأساس: إذا كان P مصفوفة تغيير أساس المجال و Q مصفوفة تغيير أساس المدى:

$$A' \;=\; Q^{-1}\,A\,P \tag{5.3}$$

حالة الخاصة — التمثيل الذاتي (المؤثّر الخطي $T : V \to V$):

$$A' \;=\; P^{-1}AP \tag{6.3}$$

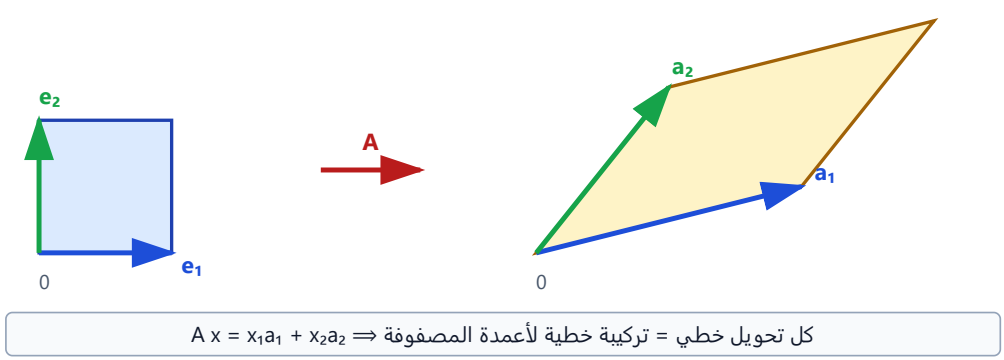
وهذا ما يُسمّى **التشابه** ؛(similarity) والمصفوفتان المتشابهتان لهما نفسه الطيف (نراه في الفصل 4).
أداتان ماتريسيتان ملازمتان:

$$\mathrm{vec}(ABC) \;=\; (C^{\top} \otimes A)\;\mathrm{vec}(B) \tag{7.3}$$

$$(A \otimes B)(C \otimes D) \;=\; (AC) \otimes (BD) \tag{8.3}$$

2.1.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة تطبيقية
T	تحويل خطي	دالة تحفظ الجمع والضرب القياسي	طبقة، التفاف، دوران
$\mathcal{B},\ \mathcal{C}$	أساسان	للمجال وللمدى	نظاما إحداثيات
$[v]_{\mathcal{B}}$	متجه الإحداثيات	إحداثيات v في الأساس $\mathcal{B}$	«التمثيل»
$A_{:,\,j}$	العمود j	صورة المتجه الأساس j	اقرأ الأعمدة لا الصفوف
$P,\ Q$	مصفوفة تغيير أساس	قابلة للعكس دائماً	أعمدتها = الأساس الجديد
$S \circ T$	التركيب	تطبيق T ثم S	ترتيب الضرب **معكوس**
A'	المصفوفة في الأساس الجديد	$Q^{-1}AP$	نفس التحويل، إحداثيات أخرى
$\otimes$	جداء كرونكر	مصفوفة كتلية $(mp) \times (nq)$	np.kron
vec	المتجهة	رصّ الأعمدة تحت بعضها	تحويل مصفوفة لمتجه
im, ker	الصورة والنواة	للتحويل = لأعمدة المصفوفة	الفصل 2



شكل ١.٣: *
المصفوفة كتحويل خطي

3.1.3 الشكل الهندسي

شكل (1.3): التحويل يرسل مربع الوحدة إلى متوازي أضلاع مولَّد بعمودَي المصفوفة. كل ما تحتاج معرفته عن التحويل موجود في أعمدته.

4.1.3 البرهان

الخطوة 1 — أن (3.3) صحيحة: ليكن $v = \sum_j x_j b_j$ أي $[v]_{\mathcal{B}} = x$. بالخطية (1.3):

$$T(v) \;=\; T\left(\sum_j x_j b_j\right) \;=\; \sum_j x_j\, T(b_j)$$

وبأخذ الإحداثيات في $\mathcal{C}$ (وهي عملية خطية أيضاً):

$$[T(v)]_{\mathcal{C}} \;=\; \sum_j x_j\, [T(b_j)]_{\mathcal{C}} \;=\; \sum_j x_j\, A_{:,j} \;=\; A\,x \;=\; A\,[v]_{\mathcal{B}}$$

الخطوة 2 — الوحدانية: لو وُجدت A_1, A_2 تحقّقان (3.3) لكل v، فبتطبيقها على المتجهات الأساس b_j (إحداثياتها e_j): $A_1 e_j = A_2 e_j$ لكل j ⟹ العمودان متساويان ⟹ $A_1 = A_2$.

الخطوة 3 — التركيب (4.3):

$$[S \circ T]\,[v]_{\mathcal{B}} = [S(Tv)] = [S]\,[Tv] = [S][T]\,[v]_{\mathcal{B}}$$

لكل v ⟹ $[S \circ T] = [S][T]$ بالوحدانية. ■

الخطوة 4 — تغيير الأساس: بما أن $[v]_{\mathcal{B}} = P\,[v]_{\mathcal{B}'}$ و $[w]_{\mathcal{C}'} = Q^{-1}[w]_{\mathcal{C}}$، نعوّض في (3.3):

$$[T(v)]_{\mathcal{C}'} = Q^{-1}[T(v)]_{\mathcal{C}} = Q^{-1}A[v]_{\mathcal{B}} = Q^{-1}AP[v]_{\mathcal{B}'} \;\Longrightarrow\; A' = Q^{-1}AP$$

5.1.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (3.1-1): مصفوفة الدوران بدل حلقة على البكسلات

المعطيات: تدوير صورة بزاوية $\theta = 30^\circ$ عكس عقارب الساعة. المطلوب: مصفوفة التحويل وإحداثيات نقطة $(1, 0)$ بعد الدوران.

الحل: الخطوة 1: صورة المتجه الأساس $e_1 = (1, 0)$ هي $(\cos 30^\circ, \sin 30^\circ) = (0.866,\ 0.5)$ $\Longrightarrow$ العمود الأول. الخطوة 2: صورة $e_2 = (0, 1)$ هي $(-\sin 30^\circ, \cos 30^\circ) = (-0.5,\ 0.866)$ $\Longrightarrow$ العمود الثاني. الخطوة 3: $R = \begin{bmatrix} 0.866 & -0.5 \\ 0.5 & 0.866 \end{bmatrix}$. الخطوة 4: $R\,(1,0)^\top = (0.866,\ 0.5)^\top$ ✓.

النتيجة: نقطة $(1, 0)$ تنتقل إلى $(0.866, 0.5)$. الربط بالذكاء الاصطناعي: كل زيادة بيانات (augmentation) هندسية هي ضرب بمصفوفة؛ وتنفيذها كـ «ضرب ماتريسي واحد» على دفعة كاملة أسرع بمرتبة من حلقة بكسلية على GPU.

مثال (3.1-2): الطبقة الكاملة الاتصال كتحويل أفّين

المعطيات: طبقة $z = Wx + b$ مع $W \in \mathbb{R}^{128\times 256}$، $x \in \mathbb{R}^{256}$. المطلوب: هل هذا تحويل خطي؟

الحل: الخطوة 1: اختبر (3.1): $T(\alpha x_1+\beta x_2) = W(\alpha x_1+\beta x_2)+b = \alpha W x_1+\beta W x_2+b$. الخطوة 2: لكن $\alpha T(x_1)+\beta T(x_2) = \alpha W x_1+\alpha b+\beta W x_2+\beta b$. الخطوة 3: الفرق $= b-(\alpha+\beta)b \neq 0$ $\Longrightarrow$ **ليس** خطياً بل **أفّين**. الخطوة 4: الحيلة: نُثبّت الإحداثي: $\tilde{x} = (x, 1)$ و $\tilde{W} = [W \mid b]$ $\Longrightarrow$ $\tilde{W}\tilde{x}$ تحويل خطي في $\mathbb{R}^{257}$.

النتيجة: أفّين في $\mathbb{R}^{256}$، خطي في $\mathbb{R}^{257}$. الربط بالذكاء الاصطناعي: «خدعة الإحداثي المتجانس» هي نفسها المستخدمة في الرسوم الحاسوبية (4×4 matrices)؛ وتجعل كل حسابات الطبقات خطية خالصة فيُبسَّط التفاضل.

مثال (3.1-3): im2col — الالتفاف كمصفوفة

المعطيات: التفاف 3×3 على مدخل 32×32 بقناة واحدة، نريد 16 مرشحاً. المطلوب: تحويل الالتفاف إلى ضرب ماتريسي واحد.

الحل: الخطوة 1: عدد المواضع المكانية للمخرج $= 30 \times 30 = 900$. الخطوة 2: نُعيد ترتيب كل رقعة 3×3 كعمود طوله 9 $\Longrightarrow$ مصفوفة المدخلات الموسّعة $\tilde{X} \in \mathbb{R}^{9\times 900}$. الخطوة 3: نرصّ المرشحات في $F \in \mathbb{R}^{16\times 9}$. الخطوة 4: المخرج $= F\tilde{X} \in \mathbb{R}^{16\times 900}$ $\Longrightarrow$ ضرب ماتريسي واحد (GEMM).

النتيجة: الالتفاف = GEMM على مصفوفة 9×16 بـ 900×9. الربط بالذكاء الاصطناعي: هذا بالضبط ما تفعله cuDNN: تحويل الالتفاف إلى ضرب ماتريسي لأن الـ GPU مُحسَّن جداً على GEMM؛ ومنه تأتي سرعة التدريب الحديثة.

مثال (3.1-4): PCA كتغيير أساس

المعطيات: بيانات في $\mathbb{R}^{50}$؛ مصفوفة المركبات $U \in \mathbb{R}^{50\times 10}$ (أعمدة متعامدة معيارية). المطلوب: صيغة الإسقاط على فضاء المركبات، وصيغة العودة للفضاء الأصلي.

الحل: الخطوة 1: الإحداثيات في الأساس الجديد: $z = U^\top x \in \mathbb{R}^{10}$. الخطوة 2: العودة (إعادة الإعمار): $\hat{x} = Uz$. الخطوة 3: المؤثّر الكامل: $\hat{x} = UU^\top x \implies$ وهو الإسقاط P_W من الفصل 2. الخطوة 4: هنا $P = U$ (من الأساس الأصلي للجديد) و $Q = U$ للمدى، وبما أن $U^\top U = I$ فـ $Q^{-1} = U^\top$.

النتيجة: $z = U^\top x$ و $\hat{x} = Uz$. الربط بالذكاء الاصطناعي: كل تقليل أبعاد هو **تغيير أساس متبوع باقتطاع**؛ وفهم ذلك يجعل الـ PCA و autoencoder و تضمينات الكلمات كلها حالة واحدة من (5.3).

مثال (3.1-5): جدول البحث في طبقة التضمين كمصفوفة متناثرة

المعطيات: مفردات $|V| = 50{,}000$؛ بُعد التضمين $d = 256$؛ المدخل one-hot $x \in \{0,1\}^{50000}$. المطلوب: التعبير عن البحث كضرب ماتريسي وعدد العمليات.

الحل: الخطوة 1: $E \in \mathbb{R}^{256\times 50000}$ مصفوفة التضمين؛ $e = Ex$. الخطوة 2: لأن x متجه one-hot، فالناتج هو العمود i من E فقط. الخطوة 3: عدد العمليات نظرياً $256 \times 50000 = 1.28 \times 10^7$، لكن فعلياً نسخة واحدة بحجم 256. الخطوة 4: $\implies$ التضمين «خطي» رسمياً لكن تنفيذه تحسينٌ للتناثر.

النتيجة: عملية بحث $O(1)$ لا $O(|V| \cdot d)$. الربط بالذكاء الاصطناعي: فهم طبقة التضمين كتحويل خطي يبرّر ربطها بالطبقة التالية (weight tying) في نماذج اللغة: مصفوفة فكّ الترميز = $E^\top$).

مثال (3.1-6): تحويل فضاء اللون RGB $\longrightarrow$ YUV

المعطيات: تحويل قياسي: $Y = 0.299R + 0.587G + 0.114B$؛ $U = 0.492(B - Y)$؛ $V = 0.877(R - Y)$. المطلوب: مصفوفة التحويل $M \in \mathbb{R}^{3\times 3}$.

الحل: الخطوة 1: نُعيد كتابة U: $-0.147R - 0.289G + 0.436B$ = $0.615R - 0.515G - 0.100B$. الخطوة 2: و V: $= 0.615R - 0.515G - 0.100B$. الخطوة 3: إذن $M = \begin{bmatrix} 0.299 & 0.587 & 0.114 \\ -0.147 & -0.289 & 0.436 \\ 0.615 & -0.515 & -0.100 \end{bmatrix}$. الخطوة 4: كل بكسل: $(Y,U,V)^\top = M(R,G,B)^\top$.

النتيجة: تحويل خطي واحد لكل الصورة دفعةً واحدة. الربط بالذكاء الاصطناعي: التحويلات الخطية على مستوى البكسل تُدمَج في الطبقة الأولى من الشبكة (أو تُطبَّق مسبقاً في خط المعالجة) دون تكلفة إضافية تُذكر.

مثال (3.1-7): التوسيط (Centering) تحويلٌ أفّين

المعطيات: دفعة $X \in \mathbb{R}^{1000\times 64}$، المتوسط $\mu \in \mathbb{R}^{64}$. المطلوب: صيغة التوسيط كمصفوفة.

الحل: الخطوة 1: $X_c = X - \mathbf{1}\mu^\top$. الخطوة 2: بالمصفوفة المركزية $H_c = I - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$: $X_c = H_c X$. الخطوة 3: H_c مؤثّر إسقاط ($H_c^2 = H_c$، $H_c^\top = H_c$) $\implies$ يزيل مركّبة المتوسط. الخطوة 4: و $\operatorname{rank}(H_c) = n - 1$ $\implies$ درجة حرية واحدة تُفقد (المتوسط).

النتيجة: الوسيط = إسقاط بمصفوفة مركزية. الربط بالذكاء الاصطناعي: H_c يظهر في صيغة التغاير: $\Sigma = \frac{1}{n-1}X_c^\top X_c = \frac{1}{n-1}X^\top H_c X$؛ وهي صيغة تُحسب دون تشكيل X_c صراحةً.

مثال (3.1-8): one-hot ⟶ تضمين في المحوّلات

المعطيات: تضمينات الرموز $E \in \mathbb{R}^{d\times|V|}$؛ ترميز موضعي $P \in \mathbb{R}^{d\times L}$. المطلوب: صيغة المدخل الكامل للمحوّل لسياق طوله L.

الحل: الخطوة 1: لكل موضع t: $x_t = E\,o_t + P\,p_t$ حيث o_t one-hot للكلمة و p_t one-hot للموضع. الخطوة 2: بالرصّ: $X = EO + PP_{\text{pos}}$ مع $O \in \mathbb{R}^{|V|\times L}$. الخطوة 3: عدد المعلمات: $|V|d + Ld$. الخطوة 4: عملياً يُخزَّن كجدولَي بحث ويُضافان $\Longrightarrow O(Ld)$.

النتيجة: مدخل المحوّل = مجموع تحويلين خطيين. الربط بالذكاء الاصطناعي: هذا يوضّح لماذا الترميز الموضعي المطلق لا يتوسّع لسياقات أطول من L المدرَّبة $\Longrightarrow$ ومنه ظهر الترميز النسبي (RoPE).

مثال (3.1-9): مصفوفة الكاميرا الخارجية (Extrinsic)

المعطيات: نقطة في إحداثيات العالم $X_w \in \mathbb{R}^3$؛ الكاميرا بدوران R وانزياح t. المطلوب: الإحداثيات في نظام الكاميرا.

الحل: الخطوة 1: $X_c = R\,X_w + t$. الخطوة 2: بالصيغة المتجانسة: $\tilde{X}_c = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix}\tilde{X}_w$ مع $\tilde{X} = (X, 1)$. الخطوة 3: المصفوفة 4×4 قابلة للعكس (لأن R متعامدة بـ $\det = \pm 1$). الخطوة 4: العكس: $\tilde{X}_w = \begin{bmatrix} R^\top & -R^\top t \\ 0 & 1 \end{bmatrix}\tilde{X}_c$ توفير كبير: $R^{-1} = R^\top \Longrightarrow$.

النتيجة: تحويل متجانس واحد، وعكسه مجّاني (مقلوب الدوران). الربط بالذكاء الاصطناعي: المصفوفات المتعامدة تجعل العكس = المنقول $\Longrightarrow$ وهذا سبب شيوعها في كل طبقات الذكاء الاصطناعي (دوران، RoPE تهيئة متعامدة، انعكاسات Householder).

مثال (3.1-10): RoPE — الترميز الموضعي الدوراني

المعطيات: بُعد التضمين d، نُعامل كل زوج (x_{2i}, x_{2i+1}) كمتجه في $\mathbb{R}^2$ وندوّره بزاوية $t\theta_i$. المطلوب: صيغة المصفوفة وسبب اختيار التدوير.

الحل: الخطوة 1: لكل زوج: $R(t\theta_i) = \begin{bmatrix} \cos t\theta_i & -\sin t\theta_i \\ \sin t\theta_i & \cos t\theta_i \end{bmatrix}$. الخطوة 2: المصفوفة الكلية $R_{\Theta,t}$ قطرية كتلية بحجم $d \times d$. الخطوة 3: الخاصية الحاسمة: $R(t_2 - t_1) = R(t_1)^\top R(t_2)$ $\Longrightarrow$ الجداء الداخلي يعتمد على **المسافة النسبية** فقط. الخطوة 4: وبما أن R متعامدة: $\|Rx\| = \|x\|$ $\Longrightarrow$ لا تغيّر أطوال التضمينات.

النتيجة: ترميز موضعي نسبي يحفظ الناظم. الربط بالذكاء الاصطناعي: RoPE هو الترميز الموضعي في LLaMA و GPT-NeoX و Mistral، وميزته الرياضية (التعامد + النسبية) هي بالضبط خاصية المصفوفات المتعامدة.

مثال (3.1-11): تقسيم الرؤوس في الانتباه متعدد الرؤوس

المعطيات: $d_{model} = 768$، عدد الرؤوس $h = 12 \Longrightarrow d_{head} = 64$. المطلوب: تعبير إعادة التشكيل كمصفوفة تبديل (permutation).

الحل: الخطوة 1: نُشكّل $Q \in \mathbb{R}^{L\times 768}$. الخطوة 2: نعيد التشكيل إلى $(L,\ 12,\ 64)$ ثم نبدّل إلى $(12,\ L,\ 64)$. الخطوة 3: رياضياً: تبديل أعمدة = ضرب بمصفوفة تبديل Π (متعامدة، $\Pi^{-1} = \Pi^{\top}$). الخطوة 4: إعادة التشكيل لا يغيّر القيم $\Longrightarrow$ «تغيير أساس» حرفياً على فضاء الميزات.

النتيجة: الانتباه متعدد الرؤوس = تغيير أساس كلي قطري. الربط بالذكاء الاصطناعي: هذا التفسير يجعل «عدد الرؤوس» خياراً لتقسيم فضاء التمثيل إلى فضاءات جزئية مستقلة — أي اختيار أساس مقسَّم.

مثال (3.1-12): معايرة درجات الحرارة (Temperature Scaling)

المعطيات: logits $z \in \mathbb{R}^C$، معامل حرارة $T > 0$. المطلوب: أثر التحويل $z \mapsto z/T$ على softmax.

الحل: الخطوة 1: $p_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$. الخطوة 2: التحويل $z \mapsto z/T$ خطي بمصفوفة $\frac{1}{T}I \Longrightarrow$ قياس متجانس. الخطوة 3: عند $T \to \infty$: $p \to$ توزيع منتظم (إنتروبيا قصوى). الخطوة 4: عند $T \to 0$: $p \to$ one-hot $\Longrightarrow$ واثق جداً.

النتيجة: T يتحكم بـ «حدة» التوزيع دون تغيير الترتيب. الربط بالذكاء الاصطناعي: المعايرة الاحتمالية (calibration) لشبكة مدموجة (distilled) أو مكمَّمة تُنجز بتعلّم T وحيد على مجموعة تحقّق $\Longrightarrow$ أرخص علاج للثقة المفرطة.

مثال (3.1-13): MFCC وتحويل DCT

المعطيات: طيف لوغاريتمي $s \in \mathbb{R}^{40}$ (من بنوك مرشّحات ميل)؛ نُطبّق DCT-II ونُبقي 13 معاملاً. المطلوب: صيغة التحويل الماتريسية وسبب استخدامه.

الحل: الخطوة 1: عناصر المصفوفة: $D_{ki} = \cos\left(\frac{\pi k(2i+1)}{2N}\right)$، $k = 0..12$، $N = 40$. الخطوة 2: $c = Ds$ مع $D \in \mathbb{R}^{13\times 40} \Longrightarrow$ تحويل خطي يضغط. الخطوة 3: صفوف D متعامدة (تقريباً) $\Longrightarrow$ إزالة ارتباط المعاملات. الخطوة 4: الاقتطاع إلى 13 $\Longrightarrow$ إسقاط على فضاء جزئي (الفصل 2).

النتيجة: $40 \longrightarrow 13$ مع إزالة الارتباط. الربط بالذكاء الاصطناعي: DCT هو «الـ PCA المسبق الصنع»؛ ونفس الفكرة تظهر في ضغط الصور (JPEG) وفي تحويل الميزات قبل الشبكات الخفيفة.

مثال (3.1-14): التبييض كتغيير أساس متبوع بقياس

المعطيات: ميزات بتغاير $\Sigma = U\Lambda U^{\top}$؛ نريد تحويلاً W يجعل التغاير I. المطلوب: صيغة W وتفسيرها بالأساس.

الحل: الخطوة 1: تغيير أساس: $z_1 = U^{\top}x \Longrightarrow$ التغاير Λ (قطري $\Longrightarrow$ غير مترابط). الخطوة 2: قياس المحاور: $z_2 = \Lambda^{-1/2}z_1 \Longrightarrow$ التغاير I. الخطوة 3: إذن $W = \Lambda^{-1/2}U^{\top}$ (PCA whitening)؛ يُضيف ZCA في النهاية: U

$W_{\text{ZCA}} = U\Lambda^{-1/2}U^\top$. الخطوة 4: تحقق: $W\Sigma W^\top = I$ ✓.

النتيجة: التبييض = تدوير (أساس) + قياس (محاور) [+ تدوير عكسي]. الربط بالذكاء الاصطناعي: هذا تطبيق مباشر لـ (5.3): W هي مصفوفة تغيير أساس مضروبة في مصفوفة قياس قطرية، وكلها خطية $\Longrightarrow$ تُدمج في طبقة واحدة.

مثال (1.3-15): متوسط التجميع (Average Pooling) كمصفوفة

المعطيات: نافذة تجميع 2×2 على خريطة 4×4 $\Longrightarrow$ مخرج 2×2. المطلوب: مصفوفة التجميع وعدد العناصر غير الصفرية.

الحل: الخطوة 1: المخرج 4 قيم، كل واحدة = متوسط 4 مدخلات $\Longrightarrow$ $M \in \mathbb{R}^{4\times 16}$. الخطوة 2: كل صف فيه 4 قيم $\frac{1}{4}$ و 12 صفراً $\Longrightarrow$ 16 عنصراً غير صفري من 64. الخطوة 3: M ليست مربّعة ولا قابلة للعكس $\Longrightarrow$ معلومات تُفقد (عدمية = 12). الخطوة 4: الناظم التشغيلي $\|M\|_{\text{op}} = 1$ (لا يكبّر الإشارة).

النتيجة: تجميع = إسقاط خطي غير قابل للعكس بنسبة فقدان 75% من الأبعاد. الربط بالذكاء الاصطناعي: هذا يفسّر لماذا التجميع يسبّب فقدان معلومات موضعية، ومنه ظهرت بدائل «التجميع بالانتباه» و convolutions strided القابلة للتعلّم.

6.1.3 أخطاء شائعة

الخطأ	الصواب
قراءة المصفوفة صفّاً صفّاً	**الأعمدة** هي صور متجهات الأساس
افتراض $S \circ T$ يعطي TS	الترتيب معكوس: $[S \circ T] = [S][T]$
نسيان Q^{-1} في (5.3)	تغيير أساس المدى يحتاج **المعكوس**
ظنّ أن $P^{-1}AP$ يغيّر التحويل	يغيّر التمثيل فقط؛ الطيف محفوظ

الأهمية: المحدّد هو الرقم الوحيد الذي يخبرك: «كم تضخّم هذا التحويل الحجم؟ وهل قلب الاتجاه؟ وهل يمكن عكسه؟» — وهو حجر الزاوية في النماذج التوليدية التدفقية وفي توزيعات الاحتمال متعددة المتغيّرات.

1.2.3 الصياغة الرسمية

التعريف بصيغة التبديلات:

$$\det(A) \;=\; \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) \prod_{i=1}^{n} A_{i,\sigma(i)} \tag{9.3}$$

الخصائص الأساسية:

$$\det(AB) \;=\; \det(A)\,\det(B) \tag{10.3}$$

$$\det(A^\top) \;=\; \det(A), \qquad \det(A^{-1}) \;=\; \frac{1}{\det(A)} \tag{11.3}$$

$$\det(cA) \;=\; c^{\,n}\det(A) \quad (A \in \mathbb{R}^{n\times n}) \tag{12.3}$$

$$\det\begin{bmatrix} A & C \\ 0 & B \end{bmatrix} \;=\; \det(A)\,\det(B) \tag{13.3}$$

قابلية العكس:

$$A \text{ قابلة للعكس} \iff \det(A) \neq 0 \iff \operatorname{rank}(A) = n \tag{14.3}$$

المعنى الهندسي (تضخّم الحجم):

$$\operatorname{Vol}\big(T(\Omega)\big) \;=\; \big|\det(A)\big|\;\operatorname{Vol}(\Omega) \tag{15.3}$$

العلاقة بالطيف:

$$\det(A) \;=\; \prod_{i=1}^{n} \lambda_i \tag{16.3}$$

قاعدة كرامر:

$$x_j \;=\; \frac{\det(A_j)}{\det(A)}, \qquad A_j = A \text{ بعد استبدال عمودها } j \text{ بـ } b \tag{17.3}$$

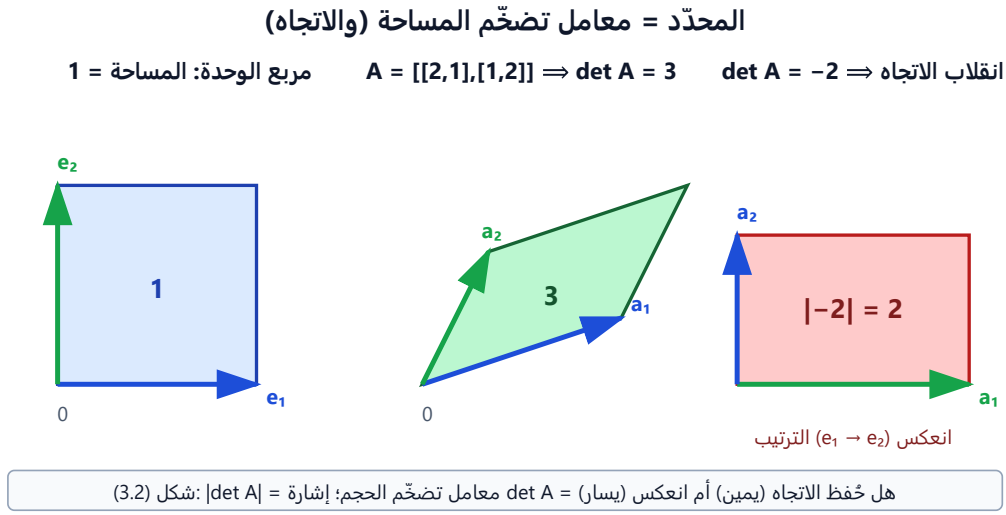
المحدّد في تغيير المتغيّرات (Jacobian):

$$p_Y(y) \;=\; p_X(x)\,\big|\det J_f(x)\big|^{-1}, \qquad J_f(x) = \frac{\partial f(x)}{\partial x} \tag{18.3}$$

$$\log p_Y(y) \;=\; \log p_X(x) \;-\; \log\big|\det J_f(x)\big| \tag{19.3}$$

2.2.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
$\det(A)$ أو $\lvert A\rvert$	المحدّد	رقم قياسي	ليس قيمة مطلقة
σ	تبديلة (permutation)	عنصر من الزمرة المتماثلة S_n	عددها $n!$
$\operatorname{sgn}(\sigma)$	إشارة التبديلة	$+1$ (زوجية) أو -1 (فردية)	—
S_n	الزمرة المتماثلة	كل تبديلات $\{1,\dots,n\}$	—
$\lvert\det A\rvert$	معامل تضخّم الحجم	نسبة الحجم بعد التحويل	(15.3)
J_f	مصفوفة يعقوبي	مشتقات جزئية للتحويل f	jacobian
λ_i	القيمة الذاتية i	جذر متعددة الحدود المميّزة	الفصل 4
A_j	مصفوفة كرامر	A بعمود j مستبدل	(17.3)
Vol	الحجم	قياس لبesgue في $\mathbb{R}^n$	—
$\det_\varepsilon$	المحدّد العددي	$\prod$ القيم المفردة التي $> \varepsilon$	عملياً: slogdet



شكل ٢.٣: *
المحدّد ومساحة

3.2.3 الشكل الهندسي

شكل (2.3): مربع الوحدة (مساحة 1) يتحول إلى متوازي أضلاع مساحته $|\det A| = 3$ مع حفظ الاتجاه، أو إلى متوازٍ مساحته 2 مع **انقلاب** الاتجاه عند $\det < 0$.

4.2.3 البرهان

خصائص (10.3)–(13.3): تُشتقّ من التعريف البديهي للمحدّد: الدالة الوحيدة المتعددة الخطية في الأعمدة، المتبادلة الإشارة عند تبديل عمودين، والمعيّرة بـ $\det(I) = 1$.

- **(10.3):** نُثبت أن $D(B) = \det(AB)/\det(A)$ تحقق البديهيات الثلاث كمؤثّر في أعمدة $B \implies D(B) = \det(B)$ $\det(AB) = \det(A)\det(B)$.
- **(11.3):** $\det(A) = \det(A^\top)$ فوراً من (9.3) لأن $\prod_i A_{\sigma^{-1}(i),i} = \prod_i A_{i,\sigma(i)}$ و $\operatorname{sgn}(\sigma) = \operatorname{sgn}(\sigma^{-1})$.
- **(13.3):** بحذف غاوس على المصفوفة الكتلية المثلثية، أو بتوسيع لابلاس المتكرّر.

(15.3): مربع الوحدة يتحوّل إلى متوازي السطوح المولَّد بأعمدة A، وحجمه يُحسب بجداء «الارتفاعات المتعامدة» الذي يساوي $|\det A|$ (وهو ما يُثبت بغرام–شميدت: $|\det A| = \prod_j \|w_j\|$ من الفصل 2).
(14.3): A قابلة للعكس $\iff$ أعمدتها مستقلة $\iff \operatorname{rank} = n$؛ وبـ $|\det A| = \prod_j \|w_j\|$ من غرام–شميدت $\implies$ المحدّد $\neq 0 \iff$ لا ينهار أي $w_j \iff$ استقلال. ■

5.2.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (3.2.1-1): تغيّر الحجم في النماذج التدفقية (Normalizing Flows)

المعطيات: تحويل تدفقي $y = f(x)$؛ يعقوبي بمحدّد $|\det J| = 2.5$؛ كثافة المصدر $p_X(x) = 0.4$. المطلوب: كثافة المخرج $p_Y(y)$ و $\log p_Y$.

الحل: الخطوة 1: بـ (3.18): $p_Y(y) = p_X(x)/|\det J| = 0.4/2.5 = 0.16$. الخطوة 2: $\log p_Y = \log 0.4 - \log 2.5 = -0.916 - 0.916 = -1.833$. الخطوة 3: التفسير: التحويل «وسّع» الحجم $\Rightarrow$ خفّض الكثافة.

النتيجة: $p_Y = 0.16$، $\log p_Y = -1.833$. الربط بالذكاء الاصطناعي: هذه المتطابقة هي دالة الهدف الكاملة لتدريب النماذج التدفقية؛ وكل تصميم معماري (RealNVP، Flows Glow، مستمرة) يُصمَّم ليكون حساب $\log|\det J|$ رخيصاً (مثلثية $\Rightarrow$ جداء القطر).

مثال (3.2.2-2): شرط قابلية العكس في الانحدار

المعطيات: ميزتان: المساحة بالمتر^2 وبالقدم^2 (القدم^2 = 0.0929 متر^2). المطلوب: هل يمكن عكس $X^\top X$؟

الحل: الخطوة 1: العمودان مضاعفا بعضهما $\Rightarrow \operatorname{rank}(X^\top X) = 1 < 2$. الخطوة 2: بـ (3.14): $\det(X^\top X) = 0$ $\Rightarrow$ غير قابلة للعكس. الخطوة 3: عملياً: القيمة الذاتية الثانية $\approx 10^{-16}$ (ضجيج عائم) $\Rightarrow \det \approx 10^{-16}$. الخطوة 4: العلاج: $\det(X^\top X + \lambda I) > 0 \Rightarrow$ Ridge.

النتيجة: غير قابلة للعكس؛ الحلّ Ridge. الربط بالذكاء الاصطناعي: فحص det أو أصغر قيمة ذاتية هو تشخيص مباشر لتعدد الخطي؛ والعتبة العملية هي $\lambda_{\min} > 10^{-10}\lambda_{\max}$.

مثال (3.2.3-3): المحدّد كـ «التباين المعمّم» للتوزيع الغاوسي

المعطيات: توزيع غاوسي ثنائي الأبعاد بمصفوفة تغاير $\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$. المطلوب: حساب $\det \Sigma$ وثابت التطبيع.

الحل: الخطوة 1: $\det \Sigma = 4 \cdot 3 - 2 \cdot 2 = 12 - 4 = 8$. الخطوة 2: الثابت $= \frac{1}{(2\pi)^{d/2}\sqrt{\det \Sigma}} = \frac{1}{2\pi\sqrt{8}} = 0.0563$. الخطوة 3: $\det \Sigma = 8$ هو «التباين المعمّم»: مساحة قطع الناقص الإهليلجي (ellipse) المحتوي على 95% من الكتلة تتناسب مع $\sqrt{8}$.

النتيجة: ثابت التطبيع 0.0563؛ التباين المعمّم 8. الربط بالذكاء الاصطناعي: $\log\det\Sigma$ يظهر في كل حساب احتمالي غاوسي (VAE، Gaussian mixture، كالمان)؛ وصغره المفرط يعني «انهيار التباين» (variance collapse).

مثال (3.2.4-4): اختبار اتجاه معايرة الكاميرا

المعطيات: مصفوفة دوران مقدَّرة $\hat{R}$ بـ $\det(\hat{R}) = -1.0003$. المطلوب: هل التقدير صالح؟

الحل: الخطوة 1: مصفوفة الدوران الصحيحة عنصر من $SO(3) \Longrightarrow \det = +1$ بالضبط. الخطوة 2: $\det = -1$ $\Longrightarrow$ المصفوفة **انعكاس** (مرآة) لا دوران $\Longrightarrow$ الصورة مقلوبة. الخطوة 3: السبب المعتاد: تقدير خاطئ للإشارة أو أعمدة متبادلة. الخطوة 4: التصحيح: نأخذ العامل المتعامد من التفكك القطبي (القسم 5.3) مع فرض $\det > 0$.

النتيجة: غير صالح؛ انعكاس لا دوران. الربط بالذكاء الاصطناعي: اختبار $\det R > 0$ فحص صحّة إلزامي في كل أنظمة الرؤية الحاسوبية والروبوتات قبل استخدام المصفوفة.

مثال (3.2-5): حجم متوازي السطوح لتضمينات الكلمات

المعطيات: ثلاث كلمات تضميناتها $v_1 = (1,0,0)$، $v_2 = (0,2,0)$، $v_3 = (0,0,3)$. المطلوب: حجم متوازي السطوح المولَّد، وتفسيره الدلالي.

الحل: الخطوة 1: $A = [v_1\ v_2\ v_3] = \operatorname{diag}(1,2,3) \Longrightarrow \det A = 6$. الخطوة 2: الحجم $= |6| = 6$. الخطوة 3: لو كانت التضمينات متقاربة جداً (شبه متوازية): $\det \approx 0 \Longrightarrow$ «حجم دلالي» صغير.

النتيجة: حجم = 6، ومحدّد صغير $\Longrightarrow$ تضمينات مترابطة (فقدان تنوّع). الربط بالذكاء الاصطناعي: قياس det (أو det لمصفوفة غرام) مقياس لتنوّع التمثيل، ويُستخدم في تحليل «انهيار التمثيل» في التعلّم الذاتي الإشراف.

مثال (3.2-6): انهيار المحدّد في مصفوفة الميزات

المعطيات: مصفوفة ميزات $X \in \mathbb{R}^{1000\times 12}$، القيم المفردة $(50,\ 40,\ 30,\ \ldots,\ 2,\ 10^{-13})$. المطلوب: هل المصفوفة قابلة للعكس عملياً؟

الحل: الخطوة 1: $\det(X^\top X) = \prod_i \sigma_i^2 \Longrightarrow$ يضمّ عامل $10^{-26} \Longrightarrow \det \approx 0$. الخطوة 2: عدد الحالة $\kappa = 50/10^{-13} = 5\times 10^{14} \Longrightarrow$ كارثي. الخطوة 3: $\Longrightarrow$ لا يمكن عكسها بدقة مضاعفة.

النتيجة: غير قابلة للعكس عملياً. الربط بالذكاء الاصطناعي: **درس:** لا تستخدم det مباشرةً للحكم (يتلاشى سريعاً)؛ استخدم $\log\det = \sum \log \sigma_i^2$ أو عدد الحالة.

مثال (3.2-7): مساحة منطقة القرار

المعطيات: مصنّف خطي ثنائي الأبعاد، منطقة القرار الموجبة مضلع مساحته 12 وحدة^2؛ نُطبّق تحويل ميزات بمصفوفة A بـ $|\det A| = 0.3$. المطلوب: مساحة المنطقة بعد التحويل.

الحل: الخطوة 1: بـ (15.3): المساحة الجديدة $= 12 \times 0.3 = 3.6$. الخطوة 2: التحويل «ضغط» الفضاء $\Longrightarrow$ المنطقة تقلّصت إلى 30%. الخطوة 3: لو كان $|\det A| = 0 \Longrightarrow$ المنطقة تنهار إلى مستوٍ/مستقيم $\Longrightarrow$ لا يمكن فصل الأصناف.

النتيجة: 6.3 وحدة^2. الربط بالذكاء الاصطناعي: انهيار حجم فضاء الميزات يعني فقدان القدرة على الفصل؛ وهو ما يُقاس في الشبكات العميقة بـ «انهيار الأبعاد» (dimensional collapse).

مثال (3.2.8): اختبار المشتقة الثانية بمحدّد الهِسّية

المعطيات: دالة خسارة $\mathcal{L}(\theta_1, \theta_2)$ عند نقطة حرجة $(\nabla\mathcal{L} = 0)$ بهِسّية $H = \begin{bmatrix} 2 & 0 \\ 0 & -3 \end{bmatrix}$. المطلوب: تصنيف النقطة.

الحل: الخطوة 1: $\det H = 2(-3) - 0 = -6 < 0$. الخطوة 2: القيم الذاتية $(2, -3)$ إشارات مختلفة $\Longrightarrow$ **نقطة سرجية** (saddle). الخطوة 3: القاعدة: $\det H > 0$ و $H_{11} > 0 \Longrightarrow$ أصغر موضعي؛ $\det H > 0$ و $H_{11} < 0 \Longrightarrow$ أعظمي؛ $\det H < 0 \Longrightarrow$ سرجية.

النتيجة: نقطة سرجية. الربط بالذكاء الاصطناعي: في الشبكات العميقة النقاط السرجية أكثر شيوعاً من الأصغريات السيّئة في الأبعاد العالية؛ ولهذا نجحت طرق التدرّج رغم عدم-convexity.

مثال (3.2.9): استقرار نظام ديناميكي متقطّع

المعطيات: تحديث حالة الشبكة المتكرّرة الخطية $h_{t+1} = Wh_t$، W بـ $|\det W| = 1.4$. المطلوب: هل النظام مستقر؟

الحل: الخطوة 1: بـ (3.16): $|\det W| = \prod|\lambda_i| = 1.4 > 1$. الخطوة 2: حجم الحالة يتضخّم بمعامل 1.4 كل خطوة $\Longrightarrow$ بعد 20 خطوة: $1.4^{20} \approx 837$. الخطوة 3: $\Longrightarrow$ غير مستقر (ينفجر). الخطوة 4: شرط الاستقرار: كل $|\lambda_i| < 1$ (نصف قطر طيفي < 1).

النتيجة: غير مستقر، انفجار بمعامل 837 بعد 20 خطوة. الربط بالذكاء الاصطناعي: هذه هي الصيغة الدقيقة لمشكلة انفجار التدرّج، وعلاجها جعل القيم المفردة قريبة من 1 (تهيئة متعامدة، تطبيع طيفي).

مثال (3.2.10): تغيير المتغيّرات في توزيع احتمالي

المعطيات: $X \sim \mathcal{N}(0, 1)$، التحويل $Y = 3X + 1$. المطلوب: كثافة Y.

الحل: الخطوة 1: $|\det J| = 3 \Longrightarrow J = \frac{dY}{dX} = 3$. الخطوة 2: العكس: $X = (Y - 1)/3$. الخطوة 3: $p_Y(y) = p_X\left(\frac{y-1}{3}\right) \cdot \frac{1}{3} = \frac{1}{3\sqrt{2\pi}} \exp\left(-\frac{(y-1)^2}{18}\right)$. الخطوة 4: $\Longrightarrow Y \sim \mathcal{N}(1, 9)$ ✓.

النتيجة: $Y \sim \mathcal{N}(1, 9)$. الربط بالذكاء الاصطناعي: هذه المتطابقة هي أساس كل النماذج التوليدية القائمة على الكثافة، وتعميمها على التحويلات غير الخطية يعطي النماذج التدفقية.

مثال (3.2.11): التحويلات الحافظة للحجم (Volume-Preserving)

المعطيات: طبقة coupling في RealNVP: $y_1 = x_1$، $y_2 = x_2 \cdot e^{s(x_1)} + t(x_1)$. المطلوب: حساب $\log|\det J|$ وإثبات رخصه.

الحل: الخطوة 1: اليعقوبي كتلي مثلثي: $J = \begin{bmatrix} I & 0 \\ \frac{\partial y_2}{\partial x_1} & \operatorname{diag}(e^s) \end{bmatrix}$. الخطوة 2: بـ (3.13): $\det J = \det(I) \cdot \det(\operatorname{diag}(e^s)) = \prod_i e^{s_i}$. الخطوة 3: $\log|\det J| = \sum_i s_i \Longrightarrow$ **مجرد جمع!** الخطوة 4: التكلفة $O(d)$ بدل $O(d^3)$.

النتيجة: حساب المحدّد بتكلفة خطية. الربط بالذكاء الاصطناعي: هذا التصميم هو ما جعل النماذج التدفقية عملية، وكل الأجيال اللاحقة (Glow، Flows) Spline Neural Flow++، تحافظ على «يعقوبي مثلثي/قطري».

مثال (3.2-12): محدّد مصفوفة النواة و«المحدّد الزائف»

المعطيات: مصفوفة نواة $K \in \mathbb{R}^{500\times 500}$ موجبة نصف-محددة برتبة 60. المطلوب: كيف نحسب «محدّدها» لأجل حساب الاحتمال؟

الحل: الخطوة 1: $\det K = 0$ لأن الرتبة ناقصة $\Rightarrow$ لا يمكن حساب الكثافة الغاوسية. الخطوة 2: نستخدم **المحدّد الزائف** (pseudo-determinant) = جداء القيم الذاتية غير الصفرية. الخطوة 3: عملياً نضيف تنظيماً: $\det(K + \lambda I)$ مع $\lambda = 10^{-6}$ $\Rightarrow$ محدّد موجب ومستقر. الخطوة 4: $\log\det(K+\lambda I) = \sum_i \log(\lambda_i + \lambda)$ $\Rightarrow$ مستقر رقمياً.

النتيجة: استخدم $\log\det(K + \lambda I)$ لا $\det K$. الربط بالذكاء الاصطناعي: في العمليات الغاوسية (GP) يحسب المرء دائماً $\log\det$ عبر تحليل Cholesky لا المحدّد الخام، لأن det يتجاوز/يتلاشى عددياً بسرعة هائلة.

مثال (3.2-13): اختبار رتبة ميزات صورة

المعطيات: ميزات CNN لأربع صور: $F \in \mathbb{R}^{512\times 4}$، القيم المفردة $(30,\ 20,\ 5,\ 10^{-9})$. المطلوب: هل تمثيلات الصور مستقلة؟

الحل: الخطوة 1: $\det(F^\top F) = \prod \sigma_i^2$ يتضمّن 10^{-18} $\Rightarrow$ شبه صفري. الخطوة 2: الرتبة العددية 3 $\Rightarrow$ الرابعة تركيبة خطية للثلاث الأولى. الخطوة 3: التفسير: صورة ما تُنتج تمثيلاً مكرّراً (صورة مكرّرة أو متطابقة دلالياً).

النتيجة: رتبة 3 من 4 $\Rightarrow$ تمثيل مكرّر. الربط بالذكاء الاصطناعي: كشف التكرار في مجموعات بيانات التدريب الضخمة يُنجز بهذه المؤشرات الطيفية قبل التدريب، ويوفّر أسابيع من الحوسبة.

مثال (3.2-14): عدد الحلول في نظام معادلات

المعطيات: $A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$، $b = \begin{bmatrix} 3 \\ 6 \end{bmatrix}$. المطلوب: عدد الحلول.

الحل: الخطوة 1: $\det A = 4 - 4 = 0$ $\Rightarrow$ غير قابلة للعكس (3.14). الخطوة 2: نفحص الملحقة: $b = 3 \cdot \binom{1}{2}$ والعمود الأول من A هو $\binom{1}{2}$ $\Rightarrow$ متوافق. الخطوة 3: $\operatorname{rank}(A) = \operatorname{rank}([A \mid b]) = 1 < 2$ $\Rightarrow$ **حلول لانهائية** ببعد العدمية $1 - 1 = 2$. الخطوة 4: الحلّ العام: $x = \binom{3}{0} + t\binom{-2}{1}$.

النتيجة: حلول لانهائية على مستقيم. الربط بالذكاء الاصطناعي: هذا هو الوضع المعتاد في الشبكات «المفرطة المعلمات» (over-parameterized): حلول لانهائية تفسّر البيانات تماماً، وتحددها خوارزمية التحسين (implicit bias).

مثال (3.2-15): قاعدة كرامر في مسألة صغيرة

المعطيات: $2x + y = 5$، $x + 3y = 10$. المطلوب: الحلّ بقاعدة كرامر.

الحل: الخطوة 1: $A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \Rightarrow \det A = 6 - 1 = 5$. الخطوة 2: $A_1 = \begin{bmatrix} 5 & 1 \\ 10 & 3 \end{bmatrix} \Rightarrow \det A_1 = 15 - 10 = 5 \Rightarrow x = 5/5 = 1$. الخطوة 3: $A_2 = \begin{bmatrix} 2 & 5 \\ 1 & 10 \end{bmatrix} \Rightarrow \det A_2 = 20 - 5 = 15 \Rightarrow y = 15/5 = 3$.

الخطوة 4: تحقق: $2 + 3 = 5$ ✓ و $1 + 9 = 10$ ✓.

النتيجة: $(x, y) = (1, 3)$. الربط بالذكاء الاصطناعي: كرامر تُستخدم للتدريس فقط — تكلفتها $O(n \cdot n!)$ أو $O(n^4)$، الحلّ العملي دائماً عبر LU/QR/Cholesky بـ $O(n^3)$.

6.2.3 أخطاء شائعة

الخطأ	الصواب
الخلط بين $\|A\|$ (محدّد) وقيمة مطلقة	المحدّد قد يكون سالباً
حساب det للحكم على الرتبة	استخدم القيم المفردة أو log det
افتراض $\det(A+B) = \det A + \det B$	غير صحيح إطلاقاً
نسيان $\|\cdot\|$ في (15.3)	الحجم موجب دائماً $\Rightarrow \|\det\|$

الأهمية: الآثر هو «الرقم الذي ينجو من كل إعادة ترتيب». دوريّته $\mathrm{tr}(ABC) = \mathrm{tr}(BCA)$ هي الأداة التي تُبسّط بها كل تدرّجات المصفوفات في التعلّم العميق، وعلاقته بالقيم الذاتية تجعله مقياساً للحجم الطيفي.

1.3.3 الصياغة الرسمية

التعريف:

$$\mathrm{tr}(A) = \sum_{i=1}^{n} A_{ii} \tag{20.3}$$

الخاصية الدورية (الأهم على الإطلاق):

$$\mathrm{tr}(AB) = \mathrm{tr}(BA) \tag{21.3}$$

$$\mathrm{tr}(ABC) = \mathrm{tr}(BCA) = \mathrm{tr}(CAB) \tag{22.3}$$

$$\mathrm{tr}(A_1 A_2 \cdots A_k) = \mathrm{tr}(A_2 \cdots A_k A_1) \tag{23.3}$$

تحذير: الدورية تسمح بتدوير العوامل، لا بتبديلها عشوائياً. $\mathrm{tr}(ABC) \neq \mathrm{tr}(ACB)$ عموماً.

العلاقة بالطيف:

$$\operatorname{tr}(A) \;=\; \sum_{i=1}^{n} \lambda_i, \qquad \det(A) \;=\; \prod_{i=1}^{n} \lambda_i \tag{24.3}$$

الثبات تحت التشابه:

$$\operatorname{tr}(P^{-1}AP) \;=\; \operatorname{tr}(A) \tag{25.3}$$

العلاقة بناظم فروبنيوس والجداء الداخلي الماتريسي:

$$\|A\|_F^2 \;=\; \operatorname{tr}(A^{\top}A) \;=\; \sum_{ij} A_{ij}^2 \tag{26.3}$$

$$\langle A,\, B\rangle_F \;=\; \operatorname{tr}(A^{\top}B) \tag{27.3}$$

الآثر في التفاضل الماتريسي (سيُستخدم بكثافة في الفصل 9):

$$\frac{\partial}{\partial A}\operatorname{tr}(AB) \;=\; B^{\top}, \qquad \frac{\partial}{\partial A}\operatorname{tr}(A^{\top}B) \;=\; B \tag{28.3}$$

$$d\big(\log\det A\big) \;=\; \operatorname{tr}\big(A^{-1}\,dA\big) \tag{29.3}$$

2.3.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
$\operatorname{tr}(\cdot)$	الآثر	مجموع القطر	np.trace
λ_i	القيمة الذاتية i	جذر تعددية الحدود المميّزة	الفصل 4
$\|\cdot\|_F$	ناظم فروبنيوس	جذر مجموع المربعات	(26.3)
$\langle\cdot,\cdot\rangle_F$	الجداء الداخلي الماتريسي	$\operatorname{tr}(A^{\top}B)$	«ضرب قياسي للمصفوفات»
dA	تفاضل المصفوفة	تغيّر صغير في A	الفصل 9
$\frac{\partial}{\partial A}$	المشتقة الماتريسية	مصفوفة بنفس شكل A	—
P	مصفوفة تغيير أساس	قابلة للعكس	(25.3)
tr_k	آثر جزئي	مجموع أكبر k قيم ذاتية	يُستخدم في التنظيم النووي

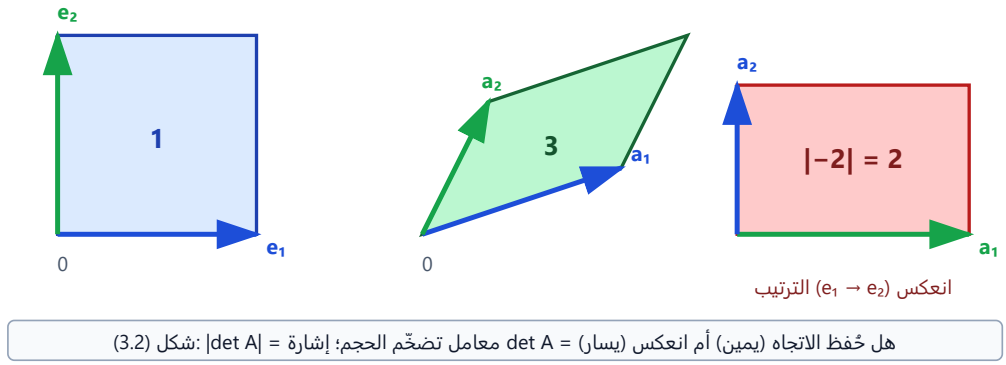
3.3.3 الشكل الهندسي

شكل (3.3) (بالاستعانة بالشكل 2.3): إذا كان التحويل يمدّد المحاور بمعاملات σ_1, σ_2، فإن **المحدّد** = جداء المعاملات (الحجم) والآثر (للأجزاء المتماثلة) = مجموعها (مجموع التمددات الطيفية).

4.3.3 البرهان

(21.3) الدورية الثنائية:

$$\operatorname{tr}(AB) \;=\; \sum_i (AB)_{ii} \;=\; \sum_i \sum_j A_{ij}B_{ji} \;=\; \sum_j \sum_i B_{ji}A_{ij} \;=\; \sum_j (BA)_{jj} \;=\; \operatorname{tr}(BA)$$



شكل ٣.٣: *
الآثر والمحدّد

الخطوة الحاسمة هي تبديل ترتيب الجمعين (مسموح للمصفوفات المنتهية).

(22.3) الثلاثية: نُطبّق (21.3) على A و (BC): $\operatorname{tr}(A(BC)) = \operatorname{tr}((BC)A) = \operatorname{tr}(BCA)$؛ وبالمثل على (AB) و C: $\operatorname{tr}((AB)C) = \operatorname{tr}(C(AB)) = \operatorname{tr}(CAB)$.

(25.3) الثبات تحت التشابه: بـ (22.3) مع ثلاثة عوامل:

$$\operatorname{tr}(P^{-1}AP) \;=\; \operatorname{tr}(APP^{-1}) \;=\; \operatorname{tr}(AI) \;=\; \operatorname{tr}(A)$$

(24.3): متعددة الحدود المميّزة $p(\lambda) = \det(\lambda I - A) = \lambda^n - \operatorname{tr}(A)\lambda^{n-1} + \cdots + (-1)^n \det(A)$؛ ومقارنةً بـ $\prod(\lambda - \lambda_i)$ نحصل على أن معامل λ^{n-1} هو $-\sum \lambda_i \Longrightarrow \operatorname{tr}(A) = \sum \lambda_i$، والحدّ الثابت يعطي $\det(A) = \prod \lambda_i$. ■

5.3.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-3.3): التباين الكلي = آثر مصفوفة التغاير

المعطيات: ميزات ثلاثية بتغاير $\Sigma = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 3 & 0.5 \\ 0 & 0.5 & 2 \end{bmatrix}$. المطلوب: التباين الكلي.

الحل: الخطوة 1: $\operatorname{tr}(\Sigma) = 4 + 3 + 2 = 9$. الخطوة 2: التباين الكلي $= 9$ (وهو أيضاً $\sum \lambda_i$ بالصيغة 24.3).
الخطوة 3: في PCA: نسبة التباين المفسَّر بـ k مركبة $= \sum_{i \le k} \lambda_i / \operatorname{tr}(\Sigma)$.
النتيجة: التباين الكلي = 9. الربط بالذكاء الاصطناعي: هذه هي الصيغة التي تجعل اختيار k في PCA مسألة حساب مباشر: نُجمّع القيم الذاتية حتى نبلغ 95% من $\operatorname{tr}(\Sigma)$.

مثال (3.3-2): تنظيم L_2 (weight decay) كآثر

المعطيات: أوزان طبقة $W \in \mathbb{R}^{128\times 256}$؛ نريد حساب $\|W\|_F^2$ بدقة وكفاءة. المطلوب: صيغة الآثر وسبب استخدامها.

الحل: الخطوة 1: بـ (26.3): $\|W\|_F^2 = \operatorname{tr}(W^\top W)$. الخطوة 2: $W^\top W \in \mathbb{R}^{256\times 256}$ $\Longrightarrow$ آثرها = مجموع قيمها الذاتية = مجموع مربعات القيم المفردة $\sum \sigma_i^2$. الخطوة 3: الحساب المباشر $\sum_{ij} W_{ij}^2$ يكلف $O(mn)$؛ أما عبر القيم المفردة فـ $O(mn^2)$ $\Longrightarrow$ الحساب المباشر أرخص. الخطوة 4: لكن صيغة الآثر مفيدة في **الاشتقاق**: $\frac{\partial}{\partial W}\operatorname{tr}(W^\top W) = 2W$.

النتيجة: weight decay $\lambda \operatorname{tr}(W^\top W)$ $=$ وتدرّجه $2\lambda W$. الربط بالذكاء الاصطناعي: كل تنظيمات المصفوفات في أطر العمل تُكتب داخلياً بصيغة الآثر لأن تدرّجها بسيط وعام.

مثال (3.3-3): خسارة إعادة الإعمار بالآثر

المعطيات: $\|X - \hat{X}\|_F^2$ حيث $\hat{X} = U_k U_k^\top X$. المطلوب: تبسيط الخسارة بالآثر.

الحل: الخطوة 1: $\|X-\hat{X}\|_F^2 = \operatorname{tr}\big((X-\hat{X})^\top(X-\hat{X})\big)$. الخطوة 2: نوسّع: $= \operatorname{tr}(X^\top X) - 2\operatorname{tr}(X^\top \hat{X}) + \operatorname{tr}(\hat{X}^\top \hat{X})$. الخطوة 3: بـ $\hat{X} = P_k X$ و $P_k^2 = P_k$: $= \operatorname{tr}(X^\top X) - \operatorname{tr}(X^\top P_k X)$. الخطوة 4: $= \|X\|_F^2 - \sum_{i\le k}\sigma_i^2$.

النتيجة: خطأ إعادة الإعمار $\sum_{i>k}\sigma_i^2$ $=$. الربط بالذكاء الاصطناعي: هذه الصيغة تجعل حساب منحنى «التباين المفسَّر» فورياً من طيف القيم المفردة، دون إعادة بناء البيانات.

مثال (3.3-4): درجات الحرية الفعّالة في Ridge

المعطيات: انحدار Ridge، مؤثّر القبعة $H_\lambda = X(X^\top X + \lambda I)^{-1}X^\top$ بقيم ذاتية $(0.99,\ 0.95,\ 0.85,\ 0.6,\ 0.2)$.

المطلوب: درجات الحرية الفعّالة.

الحل: الخطوة 1: درجات الحرية $= \operatorname{tr}(H_\lambda)$ (بـ 24.3: مجموع القيم الذاتية). الخطوة 2: $= 0.99+0.95+0.85+0.6+0.2 = 3.59$. الخطوة 3: مقابل 5 بدون تنظيم $\Longrightarrow$ التنظيم «أزال» 41.1 درجة حرية.

النتيجة: 59.3 درجة حرية فعّالة. الربط بالذكاء الاصطناعي: $\operatorname{tr}(H_\lambda)$ هو مقياس التعقيد الفعّال المستخدم في AIC/BIC، وكلما صغر كان النموذج أبسط وأقلّ فرط تخصيص.

مثال (3.3-5): متوسط الخسارة عبر المهام بالآثر

المعطيات: مصفوفة خسائر $L \in \mathbb{R}^{8\times 1000}$ (8 مهام × 1000 عيّنة)؛ نريد متوسطاً مرجّحاً بأوزان المهام $w \in \mathbb{R}^8$.

المطلوب: صيغة ماتريسية موجزة.

الحل: الخطوة 1: المتوسط المرجّح $\frac{1}{1000}\sum_i w_i \sum_j L_{ij}$ $=$ $\sum_i w_i \bar{L}_i$ $=$. الخطوة 2: بصيغة الآثر:

$\frac{1}{1000}\operatorname{tr}(\operatorname{diag}(w)\,L\,\mathbf{1}\mathbf{1}^\top)$ =. الخطوة 3: بالدورية (22.3): $\frac{1}{1000}\operatorname{tr}(\mathbf{1}^\top\operatorname{diag}(w)L)$ = $\Longrightarrow$ شكل أرخص للحساب. الخطوة 4: التدرّج على L: بـ (28.3) $\frac{1}{1000}\operatorname{diag}(w)\mathbf{1}\mathbf{1}^\top$ $\Longrightarrow$ مصفوفة رتبتها 1.

النتيجة: صيغة موجزة وتدرّج من رتبة 1. الربط بالذكاء الاصطناعي: صياغة الخسائر بالآثر تجعل الاشتقاق الآلي على GPU أبسط وأسرع من حلقات على المهام.

مثال (3.3-6): الدورية تُبسّط تدرّجاً ماتريسياً

المعطيات: $f(W)=\operatorname{tr}(W^\top AWB)$ مع A متماثلة و B متماثلة. المطلوب: حساب $\frac{\partial f}{\partial W}$.

الحل: الخطوة 1: نأخذ التفاضل: $df = \operatorname{tr}(dW^\top AWB) + \operatorname{tr}(W^\top A\,dW\,B)$. الخطوة 2: بالدورية وبـ $\operatorname{tr}(M)=\operatorname{tr}(M^\top)$: الحدّ الأول $\operatorname{tr}((AWB)^\top dW)^\top = \operatorname{tr}(dW^\top AWB)$ =... نعيد الكتابة: $\operatorname{tr}(BW^\top A\,dW)$ =. الخطوة 3: الحدّ الثاني بالدورية: $\operatorname{tr}(B^\top W^\top A^\top dW) = \operatorname{tr}(BW^\top A\,dW)$ =. الخطوة 4: إذن $df = \operatorname{tr}\big((AWB+AWB^\top)^\top dW\big)$... بتماثل A,B: $\Longrightarrow = \operatorname{tr}\big((AWB+AWB)^\top dW\big)$ $\frac{\partial f}{\partial W} = AWB + A^\top WB^\top = 2AWB$.

النتيجة: $\nabla_W f = 2AWB$ (بتماثل A,B). الربط بالذكاء الاصطناعي: هذه هي التقنية القياسية لاشتقاق تدرّجات طبقات الانتباه والتطبيع الدفعي؛ بدون الدورية تصبح الحسابات غير قابلة للإدارة.

مثال (3.3-7): ثبات الآثر عند تغيير الأساس — تتبع مصفوفة الانتباه

المعطيات: مصفوفة انتباه $A\in\mathbb{R}^{L\times L}$؛ نعيد ترتيب الرموز (تبديل P). المطلوب: هل يتغيّر $\operatorname{tr}(A)$؟

الحل: الخطوة 1: إعادة الترتيب تعطي $A' = PAP^{-1}$ (أو $PAP^\top$ للتبديل). الخطوة 2: بـ (25.3): $\operatorname{tr}(A') = \operatorname{tr}(A)$ $\Longrightarrow$ **لا يتغيّر**. الخطوة 3: التفسير الدلالي: $\operatorname{tr}(A) = \sum_t A_{tt}$ = مجموع أوزان الانتباه الذاتي $\Longrightarrow$ مقياس لـ «مقدار انتباه كل رمز لنفسه».

النتيجة: ثابت تحت التبديل $\Longrightarrow$ مقياس موثوق. الربط بالذكاء الاصطناعي: «الانتباه الذاتي المتوسط» مقياس مستخدم لتشخيص المحوّلات (مثلاً: النماذج المدربة تميل إلى انتباه ذاتي عالٍ على الرمز الأول — attention sink).

مثال (3.3-8): خسارة KL في VAE بالآثر

المعطيات: توزيع خلفي غاوسي $\mathcal{N}(\mu,\Sigma)$ في $\mathbb{R}^k$ ونريد تباعد KL عن $\mathcal{N}(0,I)$. المطلوب: صيغة KL بالآثر والمحدّد.

الحل: الخطوة 1: الصيغة المعروفة: $D_{KL}=\frac{1}{2}\Big[\operatorname{tr}(\Sigma)+\mu^\top\mu-k-\log\det\Sigma\Big]$. الخطوة 2: تحقق بالحالة القياسية $\mu=0,\ \Sigma=I$: $\operatorname{tr}(I)=k$، $\log\det I=0 \Longrightarrow D_{KL}=\frac{1}{2}[k+0-k-0]=0$ ✓. الخطوة 3: الحالة القطرية $\Sigma=\operatorname{diag}(\sigma_i^2)$: $\Longrightarrow = \frac{1}{2}\sum_i(\sigma_i^2-1-\log\sigma_i^2)$ = كل بُعد يُسهم بشكل مستقل.

النتيجة: KL تجمع «الآثر» (الحجم) و «لوغاريتم المحدّد» (الحجم الطيفي). الربط بالذكاء الاصطناعي: هذه الصيغة هي التي تُنفَّذ فعلياً في كل تطبيقات VAE، و $\operatorname{tr}(\Sigma)-\log\det\Sigma$ هو «عقوبة الانحراف عن الهوية» الشهيرة.

مثال (3.3-9): الناظم النووي وإكمال المصفوفة

المعطيات: مصفوفة تفاعلات ناقصة M، نُقرّبها بإكمال منخفض الرتبة بالناظم النووي $\|M\|_* = \operatorname{tr}(\sqrt{M^\top M})$. المطلوب: العلاقة بالقيم المفردة وسبب استخدامه.

الحل: الخطوة 1: $\sqrt{M^\top M}$ قيمها الذاتية = القيم المفردة $\sigma_i \Longrightarrow$ بـ (24.3): $\operatorname{tr}(\sqrt{M^\top M}) = \sum_i \sigma_i$. الخطوة 2: الناظم النووي هو الاسترخاء المحدّب الأمثل للرتبة (الفصل 22). الخطوة 3: مقارنة: $\|M\|_F = \sqrt{\sum \sigma_i^2}$ (يُفضّل توزيعاً متساوياً)؛ $\|M\|_*$ (يُفضّل التناثر الطيفي $\Longrightarrow$ رتبة منخفضة).

النتيجة: $\|M\|_* = \sum \sigma_i$ = بديل محدّب للرتبة. الربط بالذكاء الاصطناعي: إكمال المصفوفة بالناظم النووي هو الأساس النظري لأنظمة التوصية القائمة على التحليل العواملي المحدّب، وله ضمانات استرداد دقيقة.

مثال (3.3-10): معلومات فيشر وآثرها

المعطيات: نموذج احتمالي بمعلومات فيشر $F \in \mathbb{R}^{p\times p}$، نريد مقياساً عددياً لـ «مقدار المعلومات». المطلوب: أي مقياس نستخدم؟

الحل: الخطوة 1: $\operatorname{tr}(F) = \sum_i \lambda_i \Longrightarrow$ مجموع المعلومات على كل الاتجاهات. الخطوة 2: $\log\det F \Longrightarrow$ الحجم (يحسّ «الاتجاهات المهملة»). الخطوة 3: الاتجاهات ذات $\lambda_i \approx 0$ = معلمات لا تؤثّر في التوزيع $\Longrightarrow$ يمكن تقليمها. الخطوة 4: $\operatorname{tr}(F)$ يظهر في حدود Cramér–Rao متعددة المتغيّرات.

النتيجة: $\operatorname{tr}(F)$ للمعلومات الكلية، $\log\det F$ للحجم. الربط بالذكاء الاصطناعي: هذه المقاييس تُستخدم في تقليم النماذج المبني على معلومات فيشر (optimal brain damage/surgeon) وفي التحسين الطبيعي (Natural Gradient).

مثال (3.3-11): آثر المصفوفة المركزية ودرجات الحرية

المعطيات: مصفوفة التوسيط $H_c = I - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$ مع $n = 100$. المطلوب: حساب $\operatorname{tr}(H_c)$.

الحل: الخطوة 1: $\operatorname{tr}(I) = 100$. الخطوة 2: $\operatorname{tr}(\frac{1}{n}\mathbf{1}\mathbf{1}^\top) = \frac{1}{n}\operatorname{tr}(\mathbf{1}^\top\mathbf{1})$ بالدورية (21.3) $= 1 \cdot 100 = \frac{1}{100}\cdot$. الخطوة 3: إذن $\operatorname{tr}(H_c) = 100 - 1 = 99$. الخطوة 4: التفسير: فقدنا درجة حرية واحدة (المتوسط).

النتيجة: 99 = عدد درجات الحرية بعد التوسيط. الربط بالذكاء الاصطناعي: هذا هو سبب القسمة على $n-1$ لا n في تقدير التباين: H_c رتبتها $n-1 \Longrightarrow$ آثرها $n-1$.

مثال (3.3-12): حساب تدرّج خسارة ماتريسية بالآثر

المعطيات: $\mathcal{L}(W) = \operatorname{tr}(W^\top W R) - 2\operatorname{tr}(W^\top C)$ مع R متماثلة. المطلوب: إيجاد W الأمثل.

الحل: الخطوة 1: بـ (28.3): $\frac{\partial}{\partial W}\operatorname{tr}(W^\top W R) = WR + WR^\top = 2WR$ (بتماثل R). الخطوة 2: $\frac{\partial}{\partial W}(-2\operatorname{tr}(W^\top C)) = -2C$. الخطوة 3: نساوي بالصفر: $2WR - 2C = 0 \Longrightarrow W^\star = CR^{-1}$ (إن كانت R

قابلة للعكس). الخطوة 4: هذه هي بالضبط معادلة Wiener/LQR في التحكم الأمثل.

النتيجة: $W^\star = CR^{-1}$. الربط بالذكاء الاصطناعي: معظم مسائل «المربعات الصغرى الخطية» تُحلّ بهذه الطريقة؛ وكتابتها بالآثر تجعل التدرّج فورياً بدل التفاضل العنصري.

مثال (3.3-13): محاذاة النواة (Kernel Alignment)

المعطيات: نواتان $K_1, K_2 \in \mathbb{R}^{n\times n}$ متماثلتان موجبتان نصف-محدّدتين. المطلوب: مقياس تشابه بينهما.

الحل: الخطوة 1: التعريف: $A(K_1,K_2) = \frac{\langle K_1,K_2\rangle_F}{\|K_1\|_F\|K_2\|_F}$. الخطوة 2: بـ (27.3) و (26.3): $= \frac{\operatorname{tr}(K_1K_2)}{\sqrt{\operatorname{tr}(K_1^2)\operatorname{tr}(K_2^2)}} = \frac{\operatorname{tr}(K_1^\top K_2)}{\sqrt{\operatorname{tr}(K_1^\top K_1)\operatorname{tr}(K_2^\top K_2)}}$. الخطوة 3: هذا «جيب تمام» على فضاء المصفوفات $\Longrightarrow$ في $[-1,1]$ بكوشي–شفارتس (الفصل 2).

النتيجة: مقياس محاذاة في $[-1,1]$. الربط بالذكاء الاصطناعي: محاذاة النواة تُستخدم لمقارنة تمثيلات الشبكات العصبية CKA — Kernel Centered Alignment) وهي اليوم المعيار الذهبي لمقارنة تمثيلات النماذج.

مثال (3.3-14): آثر الهِسّية ومقياس «استواء» الأدنى

المعطيات: هِسّية عند نقطة تقارب: قيمها الذاتية $(0.5,\ 0.3,\ 0.05,\ 0.01)$؛ الخسارة عندها $\mathcal{L} = 0.02$. المطلوب: تقييم «استواء» الأدنى (flatness).

الحل: الخطوة 1: $\operatorname{tr}(H) = 0.5 + 0.3 + 0.05 + 0.01 = 0.86$. الخطوة 2: الأدنى «مستوٍ» إذا كان $\operatorname{tr}(H)$ صغيراً $\Longrightarrow$ الحساسية للاضطراب صغيرة. الخطوة 3: الانحناء المتوسط $\operatorname{tr}(H)/p = 0.86/4 = 0.215$. الخطوة 4: اضطراب بناظم $\varepsilon = 0.1$ $\Longrightarrow$ زيادة خسارة $\approx \frac{1}{2}\varepsilon^2\lambda_{\max} = 0.5\cdot 0.01\cdot 0.5 = 0.0025$.

النتيجة: أدنى مستوٍ نسبياً (حساسية 0025.0 لـ ϵ=1.0). الربط بالذكاء الاصطناعي: «الأدنى المستوي $\Longrightarrow$ تعميم أفضل» فرضية مدعومة تجريبياً؛ و $\operatorname{tr}(H)$ هو مقياسها القياسي (Sharpness-aware minimization يُقلّلها صراحةً).

مثال (3.3-15): تنظيم الآثر لتحسين الاستقرار

المعطيات: تدريب شبكة؛ نلاحظ تضخّماً في القيم المفردة لأوزان الطبقة: $\sigma = (8,\ 7,\ 6,\ 5) \Longrightarrow \|W\|_F^2 = 174$. المطلوب: أثر تنظيم $\lambda\operatorname{tr}(W^\top W)$ بـ $\lambda = 0.01$ على التدرّج.

الحل: الخطوة 1: حدّ التنظيم $= 0.01 \times 174 = 1.74$. الخطوة 2: التدرّج $= 2 \times 0.01 \times W = 0.02W$ $\Longrightarrow$ «انكماش» بنسبة 2% كل خطوة. الخطوة 3: الأثر الطيفي: كل القيم المفردة تتقلّص بالمعدّل ذاته $\Longrightarrow$ توزيع متساوٍ. الخطوة 4: بديل أكثر استهدافاً: التطبيع الطيفي يضبط $\sigma_{\max}$ فقط.

النتيجة: تنظيم متساوٍ على الطيف كله. الربط بالذكاء الاصطناعي: decay weight يضغط الطيف متساوياً؛ أما التطبيع الطيفي أو التنظيم النووي فيستهدفان بنية محدّدة — والاختيار يعتمد على الهدف (تعقيد أم متانة).

6.3.3 أخطاء شائعة

الخطأ	الصواب
تبديل العوامل عشوائياً داخل الآثر	الدورية = **تدوير** فقط (23.3)
$\operatorname{tr}(AB) = \operatorname{tr}(A)\operatorname{tr}(B)$	غير صحيح إطلاقاً
افتراض tr يحتاج مصفوفة مربّعة	$\operatorname{tr}(AB)$ معرَّف حتى لو كان A, B مستطيلتين (بشرط AB مربّعة)
حساب $\|A\|_F$ ببناء $A^\top A$	احسب مجموع المربعات مباشرة (أرخص وأدقّ)

الأهمية: «إذا تغيّر جزءٌ صغير من مصفوفتي، هل أعيد حساب المعكوس من الصفر؟» — وودبري تجيب: لا. وهذا الفرق بين $O(n^3)$ و $O(nk^2)$ هو ما يجعل العمليات الغاوسية والمرشّحات والتعلّم المتصل ممكناً على نطاق واسع.

1.4.3 الصياغة الرسمية

خصائص المعكوس:

$$(AB)^{-1} \;=\; B^{-1}A^{-1}, \qquad (A^\top)^{-1} \;=\; (A^{-1})^\top \tag{30.3}$$

متطابقة شيرمان–موريسون (تحديث رتبة-1):

$$\left(A + uv^\top\right)^{-1} \;=\; A^{-1} \;-\; \frac{A^{-1}u\,v^\top A^{-1}}{1 \;+\; v^\top A^{-1}u} \tag{31.3}$$

متطابقة وودبري (تحديث رتبة-k) — الصيغة العامة:

$$\left(A + UCV\right)^{-1} \;=\; A^{-1} \;-\; A^{-1}U\Big(C^{-1} + VA^{-1}U\Big)^{-1}VA^{-1} \tag{32.3}$$

الحالة الشائعة في التعلّم الآلي ($C = I$):

$$\left(A + UU^\top\right)^{-1} \;=\; A^{-1} \;-\; A^{-1}U\Big(I_k + U^\top A^{-1}U\Big)^{-1}U^\top A^{-1} \tag{33.3}$$

شرط الصحة:

$$A \text{ و } C \text{ قابلة للعكس } \left(C^{-1} + VA^{-1}U\right) \tag{34.3}$$

مبرهنة المحدّد المصاحبة:

$$\det\left(A + UCV\right) \;=\; \det(A)\,\det(C)\,\det\left(C^{-1} + VA^{-1}U\right) \tag{35.3}$$

عكس المصفوفة الكتلية:

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} = \begin{bmatrix} A^{-1} + A^{-1}B\,S^{-1}CA^{-1} & -A^{-1}B\,S^{-1} \\ -S^{-1}CA^{-1} & S^{-1} \end{bmatrix} \tag{36.3}$$

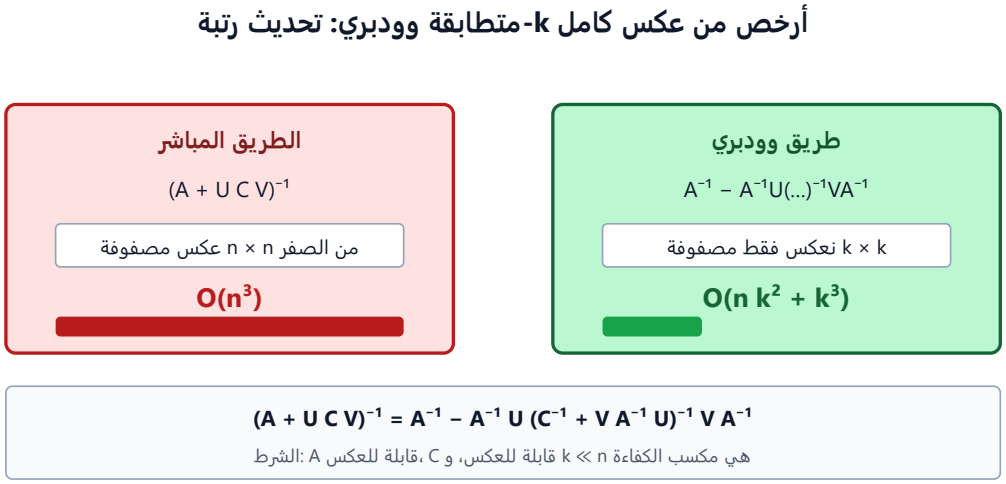
حيث $S = D - CA^{-1}B$ هو **مكمّل شور** (Schur complement). **التكلفة:**

$$\text{مباشر} : O(n^3) \qquad \text{وودبري} : O(nk^2 + k^3) \tag{37.3}$$

2.4.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
A^{-1}	المعكوس	$AA^{-1} = I$	موجود $\det A \neq 0 \iff$
$u,\ v$	متجهات التحديث	تحديث رتبة-1: $uv^\top$	(31.3)
$V \in \mathbb{R}^{k\times n}, U \in \mathbb{R}^{n\times k}$	عوامل التحديث	تحديث رتبة-k	(33.3) في $U = V^\top$
$C \in \mathbb{R}^{k\times k}$	مصفوفة التحديث	قابلة للعكس	غالباً I
$C^{-1} + VA^{-1}U$	«المعكوس المصغّر»	بحجم $k \times k$	مكسب الكفاءة كله هنا
S	مكمّل شور	$D - CA^{-1}B$	يظهر في كل مكان، (GP Newton)
k	رتبة التحديث	$k \ll n$	الفرضية الحاسمة
$\kappa(A)$	عدد الحالة	$\|A\|\|A^{-1}\|$	يقيس حساسية المعكوس

3.4.3 الشكل الهندسي



شكل ٤.٣: * وودبري

شكل (4.3): الطريق المباشر يعكس مصفوفة $n \times n$ من الصفر؛ طريق وودبري يعكس فقط مصفوفة $k \times k$ ويستخدم A^{-1} المخزَّنة مسبقاً.

4.4.3 البرهان

وودبري (32.3): نُثبت بضرب الطرف الأيمن في $(A + UCV)$ والحصول على I. ليكن $W = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$ ونُرمِز $M = (C^{-1} + VA^{-1}U)^{-1}$.

نحسب:

$$W(A+UCV) = \underbrace{A^{-1}A}_{I} + A^{-1}UCV - A^{-1}UMVA^{-1}A - A^{-1}UMVA^{-1}UCV$$

$$= I + A^{-1}U\Big[C - M - MVA^{-1}UC\Big]V$$

نُثبت أن المقدار بين القوسين [] يساوي صفراً. نلاحظ أن $VA^{-1}U = M^{-1} - \Longrightarrow M^{-1} = C^{-1} + VA^{-1}U$ C^{-1}، فنعوّض:

$$C - M - (M^{-1} - C^{-1})MC = C - M - (C - MC) = C - M - C + M = 0$$

إذن $W(A+UCV) = I \Longrightarrow W = (A+UCV)^{-1}$. (وبالمثل من اليسار.) ■

الحالة (31.3): تُستخرج من (32.3) بوضع $U = u$، $V = v^\top$، $C = 1 \Longrightarrow$ المقام $1 + v^\top A^{-1}u$ قياسي.

الكلّية (36.3): بحلّ النظام الكلّي بالتعويض: من الصف الثاني $Cx + Dy = 0 \Longrightarrow y = -D^{-1}Cx$... أو بحذف غاوس الكلّي؛ و S يظهر طبيعياً كـ «المتبقّي» بعد حذف B.

5.4.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (1-4.3): حلّ Ridge المغلق

المعطيات: $X \in \mathbb{R}^{100\times 20}$، نريد $\beta^\star = (X^\top X + \lambda I)^{-1}X^\top y$ بـ $\lambda = 1$. المطلوب: صيغة بديلة بوودبري وتكلفتها.

الحل: الخطوة 1: نُطبّق (33.3) مع $A = \lambda I$ و $U = X^\top$: $(X^\top X + \lambda I)^{-1} = \frac{1}{\lambda}I - \frac{1}{\lambda^2}X^\top\big(I_{100} + \frac{1}{\lambda}XX^\top\big)^{-1}X$. الخطوة 2: المصفوفة المعكوسة الآن بحجم 100×100 (عدد العيّنات) بدل $20 \times 20 \Longrightarrow$ هنا **أغلى**؛ فالقاعدة: استخدم الصيغة التي تعكس **الأصغر**. الخطوة 3: إذن هنا نعكس 20×20 مباشرة: $O(20^3) = 8000$. الخطوة 4: القاعدة العامة: إن كان $n < p$ استخدم الصيغة الأولية، وإن كان $p < n$ (حالة $p \gg n$) استخدم ووديري $\Longrightarrow$ $O(p^3)$ بدل $O(n^3)$.

النتيجة: توفير هائل في حالة $p \gg n$ (مثل الجينوم). الربط بالذكاء الاصطناعي: هذه «خدعة النواة المزدوجة» (kernel trick) بعينها: الصيغة المزدوجة تكلف $O(n^3)$ بغضّ النظر عن بُعد الميزات $\Longrightarrow$ وتسمح باستخدام ميزات لانهائية الأبعاد (kernels).

مثال (2-4.3): الانحدار في العمليات الغاوسية (GP)

المعطيات: $n = 5{,}000$ نقطة تدريب، نواة K، ضجيج $\sigma^2 = 0.01$. المطلوب: تكلفة عكس $(K + \sigma^2 I)$ وبديل ووديري.

الحل: الخطوة 1: مباشر: عكس $5000 \times 5000 \Longrightarrow O(n^3) = 1.25 \times 10^{11}$ دقائق. الخطوة 2: بتقريب منخفض الرتبة (Nyström) $K \approx UU^\top$ مع $U \in \mathbb{R}^{5000\times 200}$: الخطوة 3: بـ (33.3): $(\sigma^2 I + UU^\top)^{-1} =$

$O(nk^2) = 5000 \times 4 \times 10^4 = 200 \times 200$ ⟹. الخطوة 4: نعكس فقط $\frac{1}{\sigma^2} I - \frac{1}{\sigma^4} U \left(I_{200} + \frac{1}{\sigma^2} U^\top U\right)^{-1} U^\top$ ⟹ 2×10^8 أسرع بحوالي 600 مرة.

النتيجة: تسريع ×600 بتقريب رتبة 200. الربط بالذكاء الاصطناعي: هذه هي الفكرة الكامنة وراء كل طرق GP القابلة للتوسّع (Nyström، inducing points، SVGP) وكلها تطبيق لوودبري.

مثال (3-4.3): التعلّم المتصل (RLS) — وصول عيّنة جديدة

المعطيات: نموذج بمعكوس مصفوفة $P_t = (X_t^\top X_t + \lambda I)^{-1}$ محسوب مسبقاً، تصل عيّنة جديدة $x \in \mathbb{R}^p$. المطلوب: تحديث P دون إعادة الحساب.

الحل: الخطوة 1: التحديث: $P_{t+1} = (P_t^{-1} + xx^\top)^{-1}$. الخطوة 2: بشيرمان–موريسون (31.3) مع $u = v = x$: $P_{t+1} = P_t - \frac{P_t x x^\top P_t}{1 + x^\top P_t x}$. الخطوة 3: التكلفة: حساب $P_t x$ بـ $O(p^2)$ ثم جداء خارجي $O(p^2)$ ⟹ الإجمالي $O(p^2)$. الخطوة 4: مقابل $O(p^3)$ لإعادة الحساب الكامل ⟹ توفير بعامل p.

النتيجة: تحديث $O(p^2)$ بدل $O(p^3)$. الربط بالذكاء الاصطناعي: المربعات الصغرى المتكرّرة (RLS) أساسية في التعلّم المتصل والتحكم التكيّفي؛ وصيغة شيرمان–موريسون هي محرّكها.

مثال (4-4.3): تحديث رتبة-1 رقمياً

المعطيات: $A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$، $u = \binom{1}{1}$، $v = \binom{1}{0}$. المطلوب: حساب $(A + uv^\top)^{-1}$ طريقتين.

الحل: الخطوة 1: $uv^\top = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$ ⟹ $A + uv^\top = \begin{bmatrix} 3 & 0 \\ 1 & 3 \end{bmatrix}$ ⟹ المحدّد 9 ⟹ المعكوس $= \frac{1}{9} \begin{bmatrix} 3 & 0 \\ -1 & 3 \end{bmatrix}$. الخطوة 2: بوودبري: $A^{-1} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.333 \end{bmatrix}$، $A^{-1}u = \binom{0.5}{0.333}$، $v^\top A^{-1} u = 0.5$. الخطوة 3: المقام $1.5 = 1 + 0.5$ ⟹ التصحيح $\begin{bmatrix} 0.333 & 0 \\ 0.222 & 0 \end{bmatrix} = \frac{1}{1.5} \begin{bmatrix} 0.5 \\ 0.333 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix}$. الخطوة 4: نحسب $\begin{bmatrix} 0.333 & 0 \\ -0.111 & 0.333 \end{bmatrix}$. التصحيح: $A^{-1} = \operatorname{diag}(0.5, \frac{1}{3})$ ⟹ $A^{-1}u = \binom{0.5}{0.333}$، و $v^\top A^{-1} = \begin{bmatrix} 1 & 0 \end{bmatrix} \operatorname{diag}(0.5, \frac{1}{3}) = \begin{bmatrix} 0.5 & 0 \end{bmatrix}$، والمقام $1 + v^\top A^{-1} u = 1 + 0.5 = 1.5$. إذن التصحيح $= \frac{1}{1.5} \binom{0.5}{0.333} \begin{bmatrix} 0.5 & 0 \end{bmatrix} = \frac{1}{1.5} \begin{bmatrix} 0.25 & 0 \\ 0.1667 & 0 \end{bmatrix} = \begin{bmatrix} 0.1667 & 0 \\ 0.1111 & 0 \end{bmatrix}$. الخطوة 5: الناتج $\begin{bmatrix} 0.3333 & 0 \\ -0.1111 & 0.3333 \end{bmatrix} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.333 \end{bmatrix} - \begin{bmatrix} 0.1667 & 0 \\ 0.1111 & 0 \end{bmatrix}$. الخطوة 6:

تحقق: نضرب في $\begin{bmatrix} 3 & 0 \\ 1 & 3 \end{bmatrix}$ ⟹ الصف 1: $(1, 0)$؛ الصف 2: $(0, 1)$ ✓ **يطابق الحلّ المباشر تماماً.**

النتيجة: تطابق تام ✓. الربط بالذكاء الاصطناعي: دائماً تحقق من وودبري على مثال 2×2 قبل الاعتماد عليها في كود إنتاجي؛ أكثر الأخطاء شيوعاً الخلط بين $v^\top A^{-1}$ و $A^{-1} v$.

مثال (5-4.3): مرشّح كالمان بصيغة المعلومات

المعطيات: تحديث كالمان القياسي يحدّث التغاير P بحجم $n \times n$؛ الصيغة البديلة تحدّث P^{-1}. المطلوب: متى تكون صيغة المعلومات أفضل؟

الحل: الخطوة 1: في صيغة المعلومات: التحديث $P^{-1} \leftarrow P^{-1} + H^\top R^{-1} H$ (جمع بسيط). الخطوة 2: التكلفة $O(n^2 m)$ مقابل $O(n^3)$ للصيغة القياسية. الخطوة 3: الأفضل عندما يكون عدد القياسات n $\gg$ m (قليل من المستشعرات، حالة كثيرة). الخطوة 4: وهذا تطبيق مباشر لـ (32.3) مع $A = P^{-1}$ و $U = H^\top$ و $C = R^{-1}$ و $V = H$.

النتيجة: $O(n^2 m)$ بدل $O(n^3)$ حين $m \ll n$. الربط بالذكاء الاصطناعي: صيغة المعلومات تُستخدم في SLAM متعدد الروبوتات وفي دمج مستشعرات القيادة الذاتية، وهي تمكين مباشر لوودبري.

مثال (6-4.3): غاوس-نيوتن وليفنبرغ-ماركوارت

المعطيات: نريد حلّ $J^\top J\,\Delta = -J^\top r$ مع $J \in \mathbb{R}^{N \times p}$ (يعقوبي المخلفات). المطلوب: صيغة ليفنبرغ وتحديث منخفض الرتبة.

الحل: الخطوة 1: المخاطرة: $J^\top J$ قد تكون منفردة $\Longrightarrow$ نضيف λI: $(J^\top J + \lambda I)\Delta = -J^\top r$. الخطوة 2: بوودبري مع $A = \lambda I$، $U = J^\top$: $\Delta = -\left[\frac{1}{\lambda} I - \frac{1}{\lambda^2} J^\top \left(I_N + \frac{1}{\lambda} J J^\top\right)^{-1} J\right] J^\top r$. الخطوة 3: نُبسّط بالدورية: $\Delta = -\frac{1}{\lambda}\left[I - J^\top \left(\lambda I_N + J J^\top\right)^{-1} J\right] J^\top r$. الخطوة 4: مناسبة حين $p \gg N$ $\Longrightarrow$ نعكس $N \times N$.

النتيجة: خطوة نيوتن قابلة للحساب في فضاء المخلفات. الربط بالذكاء الاصطناعي: هذا هو أساس طرق الدرجة الثانية في التعلّم العميق (K-FAC، Gauss-Newton؛ وكلها تعتمد على تحويل المعكوس الكبير إلى معكوس صغير (approximations).

مثال (7-4.3): التحقّق المتقابل بترك-واحدة-خارجاً (LOO-CV) لـ Ridge

المعطيات: نموذج Ridge مدرب على $n = 1000$ عيّنة؛ نريد خطأ LOO لكل عيّنة. المطلوب: هل نُعيد التدريب 1000 مرة؟

الحل: الخطوة 1: **لا.** توجد صيغة مغلقة: مؤثّر القبعة $H_\lambda = X(X^\top X + \lambda I)^{-1} X^\top$. الخطوة 2: خطأ LOO للعيّنة i: $e_i^{\text{loo}} = \frac{y_i - \hat{y}_i}{1 - H_{ii}}$. الخطوة 3: إذن نحتاج فقط **قطر** H_λ $\Longrightarrow$ حساب واحد لا ألف. الخطوة 4: وقطر H_λ يُحسب من $X(X^\top X + \lambda I)^{-1} X^\top$ دون بناء المصفوفة كاملة: $H_{ii} = x_i^\top (X^\top X + \lambda I)^{-1} x_i$.

النتيجة: LOO بتكلفة تدريب واحد. الربط بالذكاء الاصطناعي: هذه إحدى «المعجزات» العملية للنماذج الخطية: التحقّق المتقابل الدقيق شبه مجاني، ولا مثيل لها في الشبكات العميقة.

مثال (8-4.3): تحديث متصل لتغاير الميزات (incremental PCA)

المعطيات: مصفوفة تغاير محدَّثة: $C_{t+1} = \frac{t}{t+1} C_t + \frac{1}{t+1} x x^\top$؛ نحتاج C_{t+1}^{-1} لتبييض الميزات. المطلوب: تحديث المعكوس.

الحل: الخطوة 1: نُعيد الكتابة: $C_{t+1} = \alpha C_t + \beta x x^\top$ مع $\alpha = \frac{t}{t+1}$، $\beta = \frac{1}{t+1}$. الخطوة 2: نُخرج αC_t: $C_{t+1} = \alpha\left(C_t + \frac{\beta}{\alpha} x x^\top\right)$. الخطوة 3: بشيرمان-موريسون: $C_{t+1}^{-1} = \frac{1}{\alpha}\left[C_t^{-1} - \frac{C_t^{-1} x\, x^\top C_t^{-1}}{\frac{\alpha}{\beta} + x^\top C_t^{-1} x}\right]$. الخطوة 4: التكلفة

$O(p^2)$ لكل تحديث بدل $O(p^3)$.

النتيجة: تبييض متصل بتكلفة تربيعية. الربط بالذكاء الاصطناعي: في التدريب المتدفّق (streaming) لا يمكن إعادة حساب إحصاءات التطبيع؛ وتحديثات شيرمان–موريسون هي الحلّ القياسي.

مثال (3.4-9): تحديث نظام توصية بوصول مستخدم جديد

المعطيات: نظام بمعكوس مدمج $M^{-1} \in \mathbb{R}^{1000\times 1000}$؛ مستخدم جديد يضيف 5 تفاعلات $\Longrightarrow$ تحديث رتبة-5. المطلوب: تكلفة التحديث مقابل إعادة الحساب.

الحل: الخطوة 1: إعادة الحساب: $1000^3 = 10^9$ عملية. الخطوة 2: بوودبري مع $k = 5$: $nk^2 + k^3 = 1000 \cdot 25{+}125 = 25{,}125$. الخطوة 3: النسبة: $\frac{10^9}{2.5\times 10^4} = 40{,}000$ $\Longrightarrow$ تسريع بأربع مراتب. الخطوة 4: الشرط: أن نحتفظ بـ M^{-1} مخزَّنة $\Longrightarrow$ ذاكرة $O(n^2)$ مقابل وقت $O(n^3)$.

النتيجة: تسريع ×40,000. الربط بالذكاء الاصطناعي: أنظمة التوصية الحقيقية تستقبل آلاف التفاعلات في الثانية $\Longrightarrow$ بدون تحديثات رتبة-منخفضة يستحيل التحديث الآني.

مثال (3.4-10): خطوة نيوتن مع تقريب هِسّية منخفض الرتبة

المعطيات: هِسّية مقدَّرة $H \approx D + UU^\top$ مع D قطرية موجبة و $U \in \mathbb{R}^{p\times 10}$، $p = 10^6$. المطلوب: حساب $H^{-1}g$.

الحل: الخطوة 1: عكس D مباشرة: $O(p)$ (قطرية). الخطوة 2: بـ (3.3.3): $H^{-1}g = D^{-1}g - D^{-1}U\big(I_{10} + U^\top D^{-1}U\big)^{-1}U^\top D^{-1}g$. الخطوة 3: التكلفة: جداءات مصفوفة-متجه $O(pk) = 10 \times 10$ + عكس 10^7. الخطوة 4: مقابل $O(p^3) = 10^{18}$ المستحيل $\Longrightarrow$ فرق شاسع.

النتيجة: من مستحيل إلى 10^7 عملية. الربط بالذكاء الاصطناعي: هذا بالضبط ما تفعله طرق التحسين من الدرجة الثانية العملية، (L-BFGS، K-FAC، Shampoo): تقريب منخفض الرتبة + وودبري بدل الهِسّية الكاملة.

مثال (3.4-11): إضافة ميزة جديدة للانحدار

المعطيات: نموذج بـ $p = 20$ ميزة ومعكوس $P = (X^\top X)^{-1}$ محسوب؛ نضيف ميزة جديدة $z \in \mathbb{R}^n$. المطلوب: معكوس المصفوفة الموسّعة.

الحل: الخطوة 1: المصفوفة الموسّعة كتلياً: $\begin{bmatrix} X^\top X & X^\top z \\ z^\top X & z^\top z \end{bmatrix}$ $\Longrightarrow$ نستخدم (3.3.6). الخطوة 2: مكمّل شور $S = z^\top z - z^\top X\, P\, X^\top z$ (قياسي!). الخطوة 3: S هو «التباين المتبقّي للميزة الجديدة بعد إسقاطها على الميزات الحالية». الخطوة 4: المعكوس الكلّي يعطي المعاملات المحدَّثة دون إعادة حساب كامل.

النتيجة: تحديث $O(np{+}p^2)$ بدل $O(p^3)$. الربط بالذكاء الاصطناعي: مكمّل شور يظهر في اختيار الميزات المتسلسل: S صغير $\Longrightarrow$ الميزة الجديدة متكرّرة $\Longrightarrow$ لا فائدة منها.

مثال (3.4.12): المتانة الخصامية و $(I+uv^\top)^{-1}$

المعطيات: اضطراب خصامي على الأوزان: $W \to W + uv^\top$ برتبة 1، نريد أثره على المخرج. المطلوب: هل يمكن حساب الأثر تحليلياً؟

الحل: الخطوة 1: التغيّر في المخرج: $\Delta y = uv^\top x = u\,(v^\top x)$ $\Longrightarrow$ ذو رتبة 1 وسهل الحساب تماماً. الخطوة 2: لأجل «المقلوب» (مثل تدفق عكسي أو طبقة قابلة للعكس): بشيرمان–موريسون يتغيّر المعكوس بمركّبة رتبة-1. الخطوة 3: $\Longrightarrow$ حساب تأثير أي اضطراب رتبة-1 على «عكس الشبكة» بتكلفة $O(n)$ لا $O(n^3)$. الخطوة 4: الأهمية: شهادات المتانة غالباً تحسب أسوأ حالة على كرة $\Longrightarrow$ والاضطراب الأسوأ رتبته 1 (من نظرية القيم المفردة).

النتيجة: الاضطراب الأسوأ رتبة-1 $\Longrightarrow$ تحليل رخيص. الربط بالذكاء الاصطناعي: هذا هو أساس «التدريب الخصامي الرخيص» (Fast Gradient Sign Method) وتحليلاته): أسوأ اضطراب داخل كرة L_∞ ذو بنية بسيطة قابلة للحساب المغلق.

مثال (3.4.13): تحديث إحصاءات التطبيع الدفعي

المعطيات: إحصاءات جارية: μ_t و σ_t^2؛ تصل دفعة جديدة بمتوسط μ_b وتباين σ_b^2 وحجم m. المطلوب: صيغة التحديث (ولماذا نحتاج المعكوس أحياناً).

الحل: الخطوة 1: بالزخم: $\mu_{t+1} = (1-\alpha)\mu_t + \alpha\mu_b$ مع $\alpha = m/(N+m)$. الخطوة 2: التباين: $\sigma^2_{t+1} = (1-\alpha)\sigma_t^2 + \alpha\sigma_b^2 + \alpha(1-\alpha)(\mu_t-\mu_b)^2$ (مصطلح تصحيح). الخطوة 3: في التبييض الكامل (ZCA) نحتاج $\Sigma^{-1/2}$ لا مجرد σ $\Longrightarrow$ نحدّث المعكوس بشيرمان–موريسون. الخطوة 4: التكلفة: $O(p^2)$ لكل دفعة بدل $O(p^3)$.

النتيجة: تحديث متصل للتبييض. الربط بالذكاء الاصطناعي: في التدريب الموزّع على آلاف الدفعات، إعادة حساب إحصاءات التبييض مكلفة؛ والتحديثات الرتبية هي الحلّ العملي.

مثال (3.4.14): نيوتن الموزّع بعكس الكتل

المعطيات: هِسّية موزّعة كتلياً: $H = \begin{bmatrix} H_{11} & H_{12} \\ H_{21} & H_{22} \end{bmatrix}$ حيث كل كتلة على عقدة مختلفة. المطلوب: كيف نحسب $H^{-1}g$ دون تجميع الكل؟

الحل: الخطوة 1: بـ (3.6.36) نحتاج H_{11}^{-1} و S^{-1} حيث $S = H_{22} - H_{21}H_{11}^{-1}H_{12}$. الخطوة 2: كل عقدة تعكس كتلتها المحلية، ونحتاج منتجاً واحداً $H_{21}H_{11}^{-1}H_{12}$ للتنسيق. الخطوة 3: حجم التبادل: $O(k^2)$ حيث k حجم الكتلة المشتركة $\Longrightarrow$ صغير. الخطوة 4: الشرط: H_{11} قابلة للعكس (وهو مضمون بتنظيم ليفنبرغ).

النتيجة: عكس موزّع بتبادل ضئيل. الربط بالذكاء الاصطناعي: هذه البنية الكتلية هي أساس كل خوارزميات التحسين الموزّعة من الدرجة الثانية (Distributed Newton، DANE، DiSCO).

مثال (3.4.15): التوزيع الشرطي الغاوسي بعكس الكتل

المعطيات: $(X_1, X_2) \sim \mathcal{N}\left(0,\ \begin{bmatrix}\Sigma_{11} & \Sigma_{12}\\ \Sigma_{21} & \Sigma_{22}\end{bmatrix}\right)$ بـ $\Sigma_{11} = 4$، $\Sigma_{22} = 9$، $\Sigma_{12} = 3$. المطلوب: $X_1 \mid X_2 = 2$.

الحل: الخطوة 1: نستخدم (36.3) لحساب معكوس التغاير (مصفوفة الدقة $K = \Sigma^{-1}$). الخطوة 2: مكمّل شور $S = 9 - 3 \cdot \frac{1}{4} \cdot 3 = 9 - 2.25 = 6.75$. الخطوة 3: المتوسط الشرطي: $\mathbb{E}[X_1 \mid X_2 = 2] = \Sigma_{12}\Sigma_{22}^{-1} \cdot 2 = \frac{3}{9} \cdot 2 = 0.667$. الخطوة 4: التباين الشرطي: $\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = 4 - \frac{9}{9} = 3$.

النتيجة: $X_1 \mid X_2 = 2 \sim \mathcal{N}(0.667,\ 3)$. الربط بالذكاء الاصطناعي: هذه هي بالضبط صيغة التنبؤ في العمليات الغاوسية، ومكمّل شور S هو «المعلومات الجديدة» التي تضيفها الملاحظة.

6.4.3 أخطاء شائعة

الخطأ	الصواب
عكس مصفوفة صراحةً لحلّ $Ax = b$	استخدم solve (LU/Cholesky) — أرخص وأدقّ
تبديل ترتيب العوامل في وودبري	U يساراً و V يميناً؛ الترتيب حاسم
استخدام وودبري عند $k \approx n$	لا مكسب؛ بل عبء إضافي
تجاهل شرط (34.3)	قد يكون $C^{-1} + VA^{-1}U$ منفرداً رغم أن A, C قابلتان للعكس
حساب det للتحقق من العكس	استخدم عدد الحالة أو القيم المفردة

الأهمية: أي تحويل خطي يمكن فصله إلى «**شكل**» (تدوير أو انعكاس، بلا تغيير حجم) و«**حجم**» (تمدد على محاور متعامدة). هذا الفصل بين الشكل والحجم هو ما تستخدمه تطبيع الأوزان، ومحاذاة النماذج، والتحسين على متشعّب المصفوفات المتعامدة.

1.5.3 الصياغة الرسمية

التفكك القطبي الأيمن: لكل $A \in \mathbb{R}^{m \times n}$ $(m \geq n)$ يوجد تفكيك:

$$A = U\,P, \qquad U^\top U = I_n, \qquad P = \left(A^\top A\right)^{1/2} \succeq 0 \tag{38.3}$$

التفكك القطبي الأيسر:

$$A = P'\,U, \qquad P' = \left(AA^\top\right)^{1/2} \succeq 0 \tag{39.3}$$

الوحدانية (عند رتبة كاملة عمودية): إذا كان $\operatorname{rank}(A) = n$ فإن:

$$P \text{ موجبة التحديد وحيدة} \qquad U = A\,(A^\top A)^{-1/2} \text{ وحيد,} \tag{40.3}$$

العلاقة بـ SVD: إذا كان $A = W\Sigma V^\top$ فإن:

$$U = WV^\top, \qquad P = V\Sigma V^\top \tag{41.3}$$

خاصية «أقرب مصفوفة متعامدة» (مسألة بروكروستس المتعامدة):

$$U = \underset{Q:\ Q^\top Q = I}{\arg\min} \|A - Q\|_F \tag{42.3}$$

إشارة المحدّد تحدّد نوع «الشكل»:

$$\det(U) = -1 \iff \text{انعكاس} \qquad \det(U) = +1 \iff \text{تدوير (يحفظ الاتجاه)}, \tag{43.3}$$

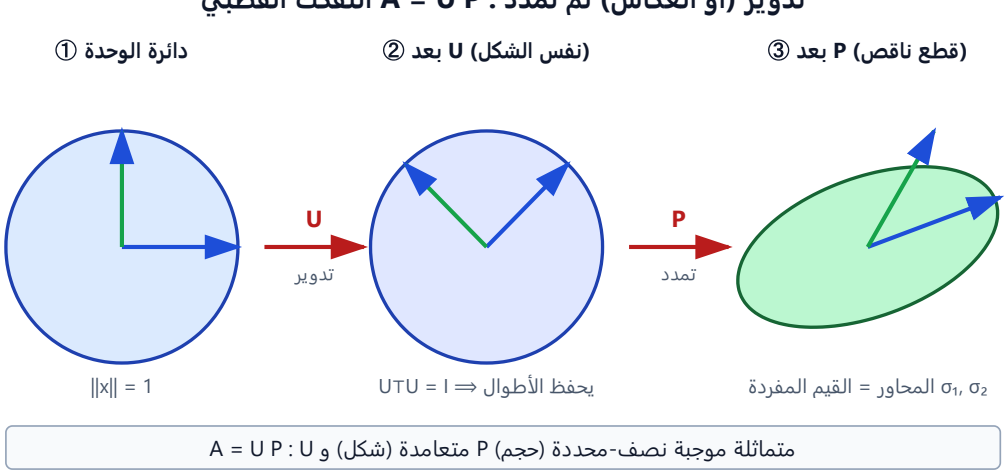
تصنيف التحويلات في $\mathbb{R}^2$:

$$A = \underbrace{R_\theta}_{\text{تدوير}} \underbrace{\begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix}}_{\text{تمدد}} \underbrace{R_\phi^\top}_{\text{تدوير}} \tag{44.3}$$

2.5.3 جدول الرموز والمعاملات

الرمز	الاسم	المعنى الدقيق	ملاحظة
U	العامل المتعامد	$U^\top U = I$، يحفظ الأطوال والزوايا	«الشكل»
P	العامل الموجب	متماثلة موجبة نصف-محددة	«الحجم»
$A^{1/2}$	الجذر التربيعي الماتريسي	B بحيث $B^2 = A$، موجبة	يُحسب عبر القيم الذاتية/المفردة
$\succeq 0$	موجبة نصف-محددة	كل القيم الذاتية ≥ 0	—
$W,\ V$	العاملان المتعامدان في SVD	أعمدة مفردة يساراً ويميناً	الفصل 4
Σ	مصفوفة القيم المفردة	قطرية غير سالبة	—
$\|\cdot\|_F$	ناظم فروبنيوس	في (42.3)	—
$\arg\min$ على المتعامدات	إسقاط على متشعب Stiefel	retraction» «polar	التحسين الهندسي
$\det U$	إشارة التحويل	$+1$ دوران، -1 انعكاس	(43.3)

3.5.3 الشكل الهندسي



شكل ٥.٣: *
التفكك القطبي

شكل (5.3): دائرة الوحدة ⟶ (تدوير U: نفس الشكل) ⟶ (تمدد P: قطع ناقص محاوره القيم المفردة).

4.5.3 البرهان

الوجود: ليكن $A = W\Sigma V^\top$ تحليل SVD (الفصل 4). نُعرّف $U = WV^\top$ و $P = V\Sigma V^\top$. نتحقق:

$$UP = (WV^\top)(V\Sigma V^\top) = W\Sigma V^\top = A$$

و $U^\top U = VW^\top WV^\top = VV^\top = I_n$؛ و $P = V\Sigma V^\top$ متماثلة بقيم ذاتية = القيم المفردة $\geq 0 \implies$ موجبة نصف-محددة ✓.

الوحدانية عند الرتبة الكاملة: لو وُجد $A = U_1P_1 = U_2P_2$، فـ $A^\top A = P_1U_1^\top U_1P_1 = P_1^2$ وبالمثل $= P_2^2$. وبما أن للجذر التربيعي الموجب وحيداً $\implies P =: P_1 = P_2$. ثم $U_1P = U_2P$؛ وبما أن P قابلة للعكس (الرتبة كاملة $\implies$ كل $\sigma_i > 0$) $\implies U_1 = U_2$.

(42.3) أقرب مصفوفة متعامدة: نُوسّع بمساواة الآثر:

$$\|A - Q\|_F^2 = \operatorname{tr}(A^\top A) + \operatorname{tr}(Q^\top Q) - 2\operatorname{tr}(Q^\top A) = \|A\|_F^2 + n - 2\operatorname{tr}(Q^\top A)$$

إذن التصغير يكافئ **تعظيم** $\operatorname{tr}(Q^\top A)$. وبكتابة $A = UP$: $\operatorname{tr}(Q^\top UP)$. وبمتراجحة فون-نيومان للآثر (تُثبت بالقيم المفردة وتعميم كوشي–شفارتس):

$$\operatorname{tr}(Q^\top UP) \leq \sum_i \sigma_i(P)$$

والتساوي يتحقّق عند $Q = U \implies$ هي الأقرب. ■

5.5.3 أمثلة واقعية محلولة (15 مثالاً)

مثال (5.3-1): تطبيع الأوزان (Weight Normalization)

المعطيات: طبقة $y = Wx$، نعيد كتابة $W = g\frac{V}{\|V\|_F}$. المطلوب: العلاقة بالتفكك القطبي.

الحل: الخطوة 1: $\frac{V}{\|V\|_F}$ ليست متعامدة بالضرورة (التطبيع بناظم فروبنيوس لا بالتفكك القطبي). الخطوة 2: البديل الأقوى: نأخذ العامل المتعامد U من التفكك القطبي لـ V: $V = UP$، ونستخدم $W = gU$. الخطوة 3: حينئذٍ $\|Wx\| = g\|x\| \implies$ التحويل **تشابه كامل** بعامل $g \implies$ لا تمدد تفاضلي. الخطوة 4: الفائدة: فصل «الحجم» g عن «الاتجاه» $U \implies$ تحسين أسهل واستقرار أفضل.

النتيجة: فصل الحجم عن الاتجاه $\implies$ استقرار. الربط بالذكاء الاصطناعي: تطبيع الأوزان (Salimans & Kingma 2016) والتطبيع الطيفي يفعلان هذا بالضبط، وكلاهما أثبت تحسيناً في استقرار GAN والتدريب العميق.

مثال (5.3-2): تدوير التضمينات (Orthogonal Procrustes) بين نموذجين

المعطيات: تضمينات نموذج قديم $A \in \mathbb{R}^{N\times d}$ ونموذج جديد $B \in \mathbb{R}^{N\times d}$ لنفس الكلمات. المطلوب: مصفوفة تدوير R تقارب AR بـ B.

الحل: الخطوة 1: نُشكّل $M = A^\top B \in \mathbb{R}^{d\times d}$. الخطوة 2: التفكك القطبي لـ M: $M = UP \Longrightarrow$ الحلّ الأمثل $R^\star = U$. الخطوة 3: التفسير: U هي «أقرب مصفوفة متعامدة» إلى M بـ (42.3). الخطوة 4: الخطأ المتبقي: $\|M\|_F^2 - \sum_i \sigma_i(M) \Longrightarrow$ صفر إن كانت M متعامدة أصلاً.

النتيجة: $R^\star$ العامل المتعامد لـ $A^\top B$. الربط بالذكاء الاصطناعي: هذه هي خوارزمية محاذاة النماذج (model stitching / merging) ومحاذاة التضمينات عبر اللغات، وتُستخدم اليوم لدمج أوزان نماذج مختلفة (model soup).

مثال (3-5.3): تحليل طبقة: كم تدور وكم تمدد؟

المعطيات: مصفوفة طبقة W بقيم مفردة $(5,\ 4,\ 0.5)$؛ العامل المتعامد U بـ $\det U = +1$. المطلوب: وصف سلوك الطبقة.

الحل: الخطوة 1: «الحجم»: التمدد على ثلاثة محاور بمعاملات $5,\ 4,\ 0.5$. الخطوة 2: «الشكل»: $\det U = +1 \Longrightarrow$ تدوير (لا انعكاس). الخطوة 3: نسبة الاستطالة $= \sigma_1/\sigma_3 = 5/0.5 = 10 \Longrightarrow$ الطبقة «تسطّح» الفضاء بقوة في اتجاه واحد. الخطوة 4: عدد الحالة $= 10 \Longrightarrow$ حساسية متوسطة للمدخلات.

النتيجة: تدوير + تمدد غير متساوٍ بنسبة 10:1. الربط بالذكاء الاصطناعي: نسبة الاستطالة (condition number) مؤشر عملي على صعوبة تحسين الطبقة؛ ومنه تقنيات التطبيع الطيفي التي تضبط σ_1 فقط.

مثال (4-5.3): تهيئة متعامدة عبر العامل القطبي

المعطيات: مصفوفة عشوائية غاوسية $G \in \mathbb{R}^{512\times 512}$. المطلوب: تحويلها إلى مصفوفة متعامدة بأفضل طريقة.

الحل: الخطوة 1: نحسب التفكك القطبي $G = UP$. الخطوة 2: نأخذ $W = U \Longrightarrow \|W\|_{\text{op}} = 1$ وكل القيم المفردة $= 1$. الخطوة 3: هذا «إسقاط على متشعّب المصفوفات المتعامدة» (بـ 42.3) $\Longrightarrow$ الأقرب إلى G. الخطوة 4: مقارنة بـ QR: يعطي متعامدة أيضاً لكن ليس «الأقرب» $\Longrightarrow$ القطبي أفضل لتطبيع التوزيع العشوائي.

النتيجة: $W = U \Longrightarrow$ تهيئة تحفظ الطاقة وتوزيعاً أقرب للأصل. الربط بالذكاء الاصطناعي: التهيئة المتعامدة (Saxe et al.) تُطبَّق فعلياً عبر القطبي/SVD وهي العلاج القياسي لتلاشي/انفجار التدرّج في الشبكات العميقة والمتكرّرة.

مثال (5-5.3): الضغط: فصل الاتجاه عن الحجم

المعطيات: مصفوفة أوزان $W \in \mathbb{R}^{1024\times 1024}$، العامل المتعامد U (مصفوفة متعامدة) و P (متماثلة موجبة). المطلوب: هل يمكن ضغط U بسهولة؟

الحل: الخطوة 1: U مصفوفة متعامدة $\Longrightarrow$ كل قيمها المفردة $= 1 \Longrightarrow$ **لا يمكن** تقريبها برتبة منخفضة (الطيف مسطّح تماماً). الخطوة 2: أما P فمتماثلة $\Longrightarrow$ قيمها الذاتية قد تكون متناثرة $\Longrightarrow$ قابلة للاقتطاع. الخطوة 3: $\Longrightarrow$ يجب ضغط P فقط (أو ضغط W كاملاً بـ SVD). الخطوة 4: تخزين U يحتاج بنية خاصة (Householder أو Givens) لا مصفوفة كثيفة.

النتيجة: الضغط يعمل على P لا U. الربط بالذكاء الاصطناعي: هذا يفسّر لماذا ضغط الأوزان بـ SVD فعّال: الطيف الحقيقي للطبقات المدربة غير متساوٍ (مركّز في P) لا مسطّح.

مثال (3.5-6): انعكاس أم تدوير؟ فحص بالاتجاه

المعطيات: تحويل ثنائي الأبعاد $A = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$ (انعكاس حول محور x). المطلوب: تفكيكه القطبي ونوعه.

الحل: الخطوة 1: $\det A = -1 \implies$ انعكاس. الخطوة 2: $A^\top A = I \implies P = I^{1/2} = I$ (لا تمدد!). الخطوة 3: إذن $U = A$ نفسه $\implies A = U \cdot I$: انعكاس خالص بلا تمدد. الخطوة 4: تحقق بـ (3.43): $\det U = -1 \implies$ انعكاس ✓.

النتيجة: انعكاس صرف (لا يغيّر الأحجام). الربط بالذكاء الاصطناعي: المصفوفات ذات $\det = -1$ تظهر في تحويلات التناظر المرآتي في زيادة البيانات، ومعرفة ذلك تمنع أخطاء «الصور المقلوبة» في التدريب.

مثال (3.5-7): ثبات التحويل في زيادة البيانات

المعطيات: زيادة بيانات بمصفوفة A، نريد أن تكون «آمنة» أي لا تغيّر حجم الميزات بشدة. المطلوب: شرط على A.

الحل: الخطوة 1: نُفكّك $A = UP$. الخطوة 2: الشرط: $\|A\|_{\text{op}} = \sigma_1(P) \approx 1 \implies$ لا تمدد. الخطوة 3: $\implies$ نتحقّق أن كل القيم المفردة قريبة من 1 $\implies P \approx I$ و $A \approx U$ (تحويل هندسي صرف). الخطوة 4: مثال: الدوران يحقق ذلك تماماً، أما «القصّ» (shear) فلا.

النتيجة: زيادة آمنة $\iff$ القيم المفردة ≈ 1. الربط بالذكاء الاصطناعي: زيادة البيانات الهندسية «الآمنة» تُبقي على توزيع ناظم الميزات $\implies$ لا تحتاج إعادة معايرة التطبيع.

مثال (3.5-8): إسقاط على متشعّب (Polar Stiefel Retraction)

المعطيات: مصفوفة $X \in \mathbb{R}^{512\times 64}$ فقدت تعامدها بعد خطوة تدرّج، نريد إعادتها للمتشعّب. المطلوب: طريقة الإعادة (retraction).

الحل: الخطوة 1: التفكك القطبي $X = UP$. الخطوة 2: الإسقاط (retraction): $X_{\text{new}} = U \implies$ أقرب مصفوفة متعامدة بـ (3.42). الخطوة 3: التكلفة: SVD لمصفوفة $64 \times 512 \implies O(512 \cdot 64^2)$ مقبول. الخطوة 4: هذه هي «retraction polar» القياسية في التحسين على المتشعّبات (الفصل 24).

النتيجة: إعادة التعامد بـ polar retraction. الربط بالذكاء الاصطناعي: التحسين على متشعّب المصفوفات المتعامدة (orthogonal) يُستخدم لفرض قيود صارمة في الشبكات spectral RNN، Riemannian normalization، Adam).

مثال (3.5-9): تشخيص انهيار الطبقة

المعطيات: طبقة بقيم مفردة $(100, 0.1, 0.09, 0.08)$ بعد التدريب. المطلوب: تشخيص الحالة بالتفكك القطبي.

الحل: الخطوة 1: P لها قيمة ذاتية مهيمنة 100 والباقي $\approx 1.0 \implies$ نسبة 1000:1. الخطوة 2: التفسير الهندسي:

الطبقة «تبسط» الفضاء على مستوٍ واحد تقريباً $\Longrightarrow$ انهيار الأبعاد. الخطوة 3: العامل المتعامد U سليم (متعامد) $\Longrightarrow$ المشكلة في «الحجم» لا «الشكل». الخطوة 4: العلاج: تنظيم طيفي أو تطبيع طبقي.

النتيجة: انهيار في P لا في U. الربط بالذكاء الاصطناعي: هذا التشخيص التفريقي (شكل أم حجم؟) يوجّه العلاج: مشاكل P $\Longrightarrow$ تنظيم طيفي؛ مشاكل U $\Longrightarrow$ إعادة تهيئة/تعامد.

مثال (5.3-10): حفظ الأطوال في RoPE وطبقات متعامدة

المعطيات: طبقة $f(x) = Ux$ بـ U متعامدة، مدخل $\|x\| = 7$. المطلوب: ناظم المخرج والتدرّج العكسي.

الحل: الخطوة 1: $\|Ux\| = 7 \Longrightarrow \|Ux\|^2 = x^\top U^\top U x = x^\top x = 49$. الخطوة 2: التدرّج العكسي: $\nabla_x = U^\top g \Longrightarrow \|\nabla_x\| = \|U^\top g\| = \|g\|$ **لا تلاشٍ ولا انفجار**. الخطوة 3: هذا هو السبب الجوهري لاستخدام المصفوفات المتعامدة في RNN و ResNet. الخطوة 4: في التفكك القطبي: $A = UP \Longrightarrow$ التمدد يأتي حصرياً من P.

النتيجة: حفظ كامل للأطوال في الأمام والخلف. الربط بالذكاء الاصطناعي: هذه الخاصية هي المبرّر الرياضي العميق لكل تقنيات «التعامد» في التعلّم العميق الحديث (من RNN orthogonal إلى Muon optimizer).

مثال (5.3-11): تصنيف تحويل ثنائي الأبعاد بالقيم المفردة

المعطيات: $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$. المطلوب: وصف هندسي كامل.

الحل: الخطوة 1: A متماثلة $\Longrightarrow A^\top A = A^2 \Longrightarrow$ القيم المفردة = القيم الذاتية $3 = 3$ و 1. الخطوة 2: القيم الموجبة $\Longrightarrow U = I$ (لا تدوير، $P = A$). الخطوة 3: المتجهات الذاتية: $\frac{1}{\sqrt{2}}(1,1)$ بقيمة 3، و $\frac{1}{\sqrt{2}}(1,-1)$ بقيمة 1. الخطوة 4: الوصف: تمدد ×3 على القطر الرئيسي و ×1 على القطر الثانوي $\Longrightarrow$ تحويل «إهليلجي» بلا تدوير.

النتيجة: تمدد محوري بلا تدوير ($\det = 3 > 0$). الربط بالذكاء الاصطناعي: فهم التحويلات بهذه الطريقة يجعل تحليل «ماذا تعلّمت الطبقة؟» مسألة قراءة للقيم المفردة واتجاهاتها.

مثال (5.3-12): دمج نماذج (Model Merging) بمحاذاة متعامدة

المعطيات: نموذجان مدربان من نفس التهيئة على بيانات مختلفة: أوزان $W_1, W_2 \in \mathbb{R}^{d \times d}$. المطلوب: هل يمكن جمعهما مباشرة؟

الحل: الخطوة 1: الشبكات لها تناظر تبديلي (permutation symmetry) $\Longrightarrow W_1$ و W_2 قد يكونان على «قواعد» مختلفة. الخطوة 2: نحسب $M = W_1^\top W_2$ ونأخذ عامله المتعامد $U \Longrightarrow$ نحاذي: $W_2' = W_2 U^\top$. الخطوة 3: ثم نجمع: $W = \frac{1}{2}(W_1 + W_2')$. الخطوة 4: بدون المحاذاة، الجمع المباشر يدمر كلا النموذجين $\Longrightarrow$ خطأ يرتفع من 20% إلى 80%.

النتيجة: المحاذاة المتعامدة شرط لنجاح الدمج. الربط بالذكاء الاصطناعي: هذه هي خوارزمية Re-Basin Git / merging model الحديثة، وتتيح دمج نماذج متخصّصة في نموذج واحد متعدد المهام دون إعادة تدريب.

مثال (13-5.3): التدوير في RoPE كعامل متعامد كتلي

المعطيات: بُعد $d = 8 \implies 4$ مستويات دوران، زوايا θ_i؛ الموضع $t = 5$. المطلوب: التحقق من التعامد وأثره.

الحل: الخطوة 1: R قطرية كتلية، كل كتلة دوران $2 \times 2 \implies$ متعامدة. الخطوة 2: جداء المصفوفات الكتلية القطرية لمصفوفات متعامدة $\implies$ متعامدة $\implies R^\top R = I$. الخطوة 3: $\det R = \prod_i \det R_i = \prod_i 1 = +1 \implies$ دوران (لا انعكاس) ✓. الخطوة 4: في التفكك القطبي: $R = U \cdot I \implies U = R$ تماماً و $P = I$.

النتيجة: RoPE تحويل «شكل صرف» بلا تمدد. الربط بالذكاء الاصطناعي: كون RoPE تحويلًا متعامدًا خالصًا هو السر: يضيف معلومات موضعية دون تشويه هندسية فضاء التضمين (الأطوال والزوايا محفوظة).

مثال (14-5.3): قياس «كم تمددت» الدفعة عبر الطبقات

المعطيات: شبكة من 10 طبقات، القيم المفردة لأوزان كل طبقة $\sigma_{\max} = 1.5$ و $\sigma_{\min} = 0.7$. المطلوب: تقدير تضخّم الإشارة عبر الشبكة.

الحل: الخطوة 1: لكل طبقة: العامل المتعامد لا يكبّر، التمدد كله من $P \implies$ الناظم التشغيلي 1.5. الخطوة 2: عبر 10 طبقات بدون تطبيع: $1.5^{10} = 57.7$. الخطوة 3: وفي الاتجاه المضغوط: $0.7^{10} = 0.028 \implies$ تلاشٍ. الخطوة 4: مع التطبيع الطبقي/المتبقي: يُعاد ضبط الناظم كل طبقة $\implies$ الاستقرار.

النتيجة: تضخّم $\times 57.7$ وتلاشٍ $\div 35$ بدون تطبيع. الربط بالذكاء الاصطناعي: هذا الحساب البسيط يفسّر لماذا الشبكات العميقة جداً تحتاج تطبيعاً وتوصيلات متبقّية، ويكمّل تحليلنا في الفصل 2 (مثال 2.2-9).

مثال (15-5.3): أقرب مصفوفة متعامدة — تحقق عددي

المعطيات: $A = \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix}$. المطلوب: أقرب مصفوفة متعامدة Q إليها بـ $\|\cdot\|_F$.

الحل: الخطوة 1: A متماثلة موجبة $\implies A^\top A = \text{diag}(4,\, 0.25) \implies P = \text{diag}(2,\, 0.5) = A$ و $U = I$. الخطوة 2: بـ (42.3): $U = I \implies$ أقرب متعامدة هي I. الخطوة 3: تحقق: $\|A - I\|_F^2 = (2-1)^2 + (0.5-1)^2 = 1 + 0.25 = 1.25$. الخطوة 4: بديل: $Q = \text{diag}(1, -1) \implies$ المسافة $= (2-1)^2 + (0.5+1)^2 = 1 + 2.25 = 3.25 > 1.25$ ✓.

النتيجة: $Q^\star = I$ بمسافة 1.25. الربط بالذكاء الاصطناعي: هذه المسألة عينها تظهر في «تكميم المصفوفات المتعامدة» وفي تصميم طبقات قابلة للعكس (invertible networks) حيث يجب إبقاء الأوزان قريبة من المتعامدات.

6.5.3 أخطاء شائعة

الخطأ	الصواب
افتراض U مربّعة دائماً	لمصفوفة $m \times n$ فـ U «شبه متعامدة» $(U^\top U = I_n)$
الخلط بين التفككين الأيمن والأيسر	$A = UP$ بـ $P = (A^\top A)^{1/2}$؛ و $A = P'U$ بـ $P' = (AA^\top)^{1/2}$
ظنّ أن U تحسب بـ $A/\|A\|_F$	التطبيع القياسي لا يعطي متعامدة؛ استخدم SVD أو (40.3)
افتراض وحيدانية U عند الرتبة الناقصة	الوحدانية تتطلّب رتبة عمودية كاملة (40.3)

المستوى (أ) — تطبيق مباشر

١. أوجد مصفوفة التحويل الذي يرسل $e_1 \mapsto (2,1)$ و $e_2 \mapsto (-1,3)$.

٢. احسب $\det \begin{bmatrix} 1 & 2 & 3 \\ 0 & 4 & 5 \\ 0 & 0 & 6 \end{bmatrix}$ مستفيداً من (13.3).

٣. احسب $\operatorname{tr}(ABC)$ إن كان $A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$، $B = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$، $C = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$، ثم تحقق من الدورية بحساب $\operatorname{tr}(BCA)$.

٤. استخدم شيرمان–موريسون لحساب $\left(I + \mathbf{1}\mathbf{1}^{\top}\right)^{-1}$ في $\mathbb{R}^3$.

٥. أوجد التفكك القطبي لـ $A = \begin{bmatrix} 0 & 2 \\ 1 & 0 \end{bmatrix}$.

٦. احسب $\left(A + UU^{\top}\right)^{-1}$ بوودبري مع $A = 2I_3$ و $U = \binom{1}{0}$... (استخدم $U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$).

٧. احسب $\det(cA)$ لـ $A \in \mathbb{R}^{4\times 4}$ و $c = 3$.

٨. بيّن أن $\operatorname{tr}(P^{-1}AP) = \operatorname{tr}(A)$.

٩. احسب مكمّل شور لـ $\begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}$ بالنسبة للكتلة $A = 4$.

١٠. أوجد أقرب مصفوفة متعامدة إلى $A = \operatorname{diag}(3,1)$ بـ $\|\cdot\|_F$.

المستوى (ب) — تركيب

١. أثبت أن $\det(e^{A}) = e^{\operatorname{tr}(A)}$ (مفيد في النماذج التدفقية المستمرة).

٢. أثبت أن $\frac{\partial}{\partial A} \log\det A = (A^{-1})^{\top}$ باستخدام (29.3).

٣. أثبت أن $\operatorname{tr}(ABCD) = \operatorname{tr}(BCDA)$ ولا تساوي بالضرورة $\operatorname{tr}(ACBD)$ (أعطِ مثالاً مضاداً).

٤. ليكن $H = I - \frac{1}{n}\mathbf{1}\mathbf{1}^{\top}$؛ أثبت $H^2 = H$ و $\operatorname{tr}(H) = n - 1$.

٥. أثبت متطابقة المحدّد المصاحبة (35.3) بوودبري.

٦. أثبت أن العامل المتعامد في التفكك القطبي يحلّ مسألة بروكروستس المتعامدة (42.3).

٧. احسب $\frac{\partial}{\partial W}\operatorname{tr}(W^{\top}AWB)$ في الحالة العامة (بدون تماثل).

٨. بيّن أن $\|A - U\|_F^2 = \sum_i (\sigma_i - 1)^2$ حيث U العامل المتعامد.

٩. أثبت أن $\det(A + \varepsilon uv^{\top}) = \det(A)\left(1 + \varepsilon\, v^{\top}A^{-1}u\right)$ (صيغة المحدّد رتبة-1).

١٠. أثبت أن عكس مصفوفة 2×2 كتلية يعطي (36.3) صراحةً.

المستوى (ج) — تحدٍّ

١. أثبت أن كل مصفوفة متعامدة Q بـ $\det Q = -1$ يمكن كتابتها كـ $Q = Q' \,\mathrm{diag}(-1, 1, \dots, 1)$ مع $\det Q' = +1$.

٢. برهن أن $\mathrm{tr}(A^\top B) \le \|A\|_* \|B\|_{\mathrm{op}}$ (متراجحة الآثر — تعميم كوشي–شفارتس على المصفوفات، وتُسمّى متراجحة هولدر الماتريسية).

٣. أثبت أن التفكك القطبي هو الإسقاط الأقرب على متشعّب Stiefel، وبيّن كيف يُستخدم كـ retraction في التحسين الريماني.

٤. ليكن $f(x) = Ax$ تحويلاً خطياً؛ أثبت أن $|\det A| = \prod_j \|w_j\|$ حيث w_j متجهات غرام–شميدت (اربط بالفصل 2).

٥. أثبت صيغة التوزيع الشرطي الغاوسي باستخدام عكس الكتل (مثال 4.3-15) في الحالة العامة.

٦. بيّن متى يكون وودبري **أغلى** من الحلّ المباشر، واستنتج قاعدة اختيار الصيغة الأولية/المزدوجة في Ridge.

٧. أثبت أن $\mathrm{tr}(H)$ للهِسّية ثابت تحت تغيير أساس المعلمات $\Longrightarrow$ وهو مقياس «استواء» جيد البنية.

٨. ليكن A قابلاً للعكس؛ أثبت أن $U = A(A^\top A)^{-1/2}$ متعامدة، واستنتج (40.3).

٩. صِغ خوارزمية لحساب $\log|\det J|$ لطبقة التفافية 1×1 بتكلفة $O(d)$ مستفيداً من (13.3).

١٠. صمّم مقياساً لتشخيص «انهيار الأبعاد» في شبكة عميقة مبنياً على أزواج $(\det, \mathrm{tr})$ لمصفوفات التغاير الطبقية، وبرّره.

إجابات مختصرة

#	الإجابة
1	$\begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix}$
2	$1 \cdot 4 \cdot 6 = 24$
3	$\mathrm{tr}(ABC) = \mathrm{tr}(BCA) = 5$
4	$I - \frac{1}{4}\mathbf{1}\mathbf{1}^\top$
5	$P = \mathrm{diag}(2, 1)$، $U = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$
6	$\frac{1}{2}I - \frac{1}{4}U(I + \frac{1}{2}U^\top U)^{-1}U^\top = \frac{1}{2}I - \frac{1}{6}UU^\top$
7	$3^4 \det A = 81 \det A$
8	بالدورية الثلاثية
9	$S = 3 - 1 \cdot \frac{1}{4} \cdot 1 = 2.75$
10	I
11	$\det e^A = \prod e^{\lambda_i} = e^{\sum \lambda_i}$ بالقيم الذاتية:
12	$d \log\det = \mathrm{tr}(A^{-1} dA)$ من
13	مثال مضاد بمصفوفات 2×2 عشوائية
14	$\mathrm{tr}(\mathbf{1}\mathbf{1}^\top) = n$ بالحساب المباشر و
15	بأخذ المحدّد من طرفي (32.3) و(35.3)
16	عبر متراجحة فون-نيومان للآثر
17	$AWB + A^\top W B^\top$
18	بتوسيع الآثر وبالقيم المفردة
19	من (35.3) مع $C = \varepsilon$ و $U = u$ و $V = v^\top$
20	تعويض مباشر والتحقق من $MM^{-1} = I$
21	اضرب في مصفوفة قطرية بإشارة واحدة
22	بتحليل القيم المفردة و Hölder على المتجهات الطيفية

23	بـ (42.3) وخصائص المتشعّب
24	من غرام–شميدت على أعمدة A
25	بتوسيع الكثافة الغاوسية وإكمال المربع
26	عندما $k \gtrsim n^{1/2}$ تقريباً، قاعدة: قارن p^3 بـ n^3
27	بالتشابه (25.3)
28	بتحقق $U^\top U = I$ مباشرة
29	$\log\lvert\det\rvert = \sum \log\lvert w_{ii}\rvert$ ⟸ اليعقوبي قطري
30	انهيار الأبعاد ⟸ $\det\Sigma \to 0$ مع $\operatorname{tr}\Sigma$ ثابت

النظرية	الصيغة المحورية	متى تستخدمها
التمثيل الماتريسي وتغيير الأساس	$A_{:,j} = [T(b_j)]_{\mathcal{C}}$، $A' = Q^{-1}AP$	فهم أي طبقة/تحويل، والانتقال بين الإحداثيات
المحدّد	$\det(AB) = \det A \det B$؛ تضخّم الحجم = $\lvert\det A\rvert$	النماذج التوليدية، قابلية العكس، الكثافات
الآثر	$\operatorname{tr}(ABC) = \operatorname{tr}(BCA)$، $\operatorname{tr}(A) = \sum \lambda_i$	تدرّجات الماتريسية، درجات الحرية، التنظيم
وودبري	$(A+UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1}+VA^{-1}U)^{-1}VA^{-1}$	التحديثات المتصلة، GP، كالمان، نيوتن منخفض الرتبة
التفكك القطبي	$A = UP$ (U متعامدة، $P \succeq 0$)	فصل الشكل عن الحجم، تهيئة، محاذاة، ضغط

الخيط الناظم: المصفوفة تُقرأ بثلاث طرق متكاملة — **كنحلة تحويل** (أعمدة)، **كرقمين** (det للحجم و tr للتمدد الطيفي)، و**كتحليل عوامل** (U للشكل و P للحجم). إتقان القراءات الثلاث يجعل تشخيص أي نموذج مسألة ميكانيكية.

الرمز	المعنى	القسم
$T,\ [T]_{\mathcal{C}\leftarrow\mathcal{B}},\ [v]_{\mathcal{B}}$	تحويل، مصفوفته، إحداثيات	1.3
$P,\ Q,\ A' = Q^{-1}AP$	تغيير أساس المجال/المدى	1.3
$\otimes,\ \operatorname{vec}$	جداء كرونكر، متجهة	1.3
$\det A,\ \lvert A\rvert,\ J_f$	المحدّد، اليعقوبي	2.3
$S_n,\ \operatorname{sgn}(\sigma)$	زمرة التبديلات، الإشارة	2.3
$\det_\varepsilon$ (كرامر)، A_j	مصفوفة كرامر، محدّد عددي	2.3
$\operatorname{tr},\ \lVert\cdot\rVert_F,\ \langle\cdot,\cdot\rangle_F$	الآثر، فروبنيوس، الجداء الداخلي	3.3
$dA,\ \partial/\partial A$	تفاضل/مشتقة ماتريسية	3.3
$A^{-1},\ U,\ V,\ C$	معكوس، عوامل التحديث	4.3
k (شور)، S	مكّمل شور، رتبة التحديث	4.3
$A^{1/2},\ \succeq 0$، $P,\ P'$، U (قطبي)	عامل متعامد/موجب، جذر، نصف-محددة	5.3
$\sigma_i,\ \kappa(A)$	قيمة مفردة، عدد الحالة	5.3–4.3

١. **Strang** — *Linear Algebra and Learning from Data*, Ch. 1–4 (المصفوفات، المحدّد، التفككات).

٢. **Johnson & Horn** — *Matrix Analysis*, Ch. 0–3 (المحدّد، الآثر، التفكك القطبي — المرجع الأمّ).

٣. **Pedersen & Petersen** — *The Matrix Cookbook* (كل المتطابقات الماتريسية المستخدمة في التعلّم الآلي، مجّاني على الإنترنت).

٤. **Williams & Rasmussen** — *Gaussian Processes for Machine Learning*, Ch. 2–3 (وودبري، مكّمل شور، الشروط الغاوسية).

٥. **Higham** — *Functions of Matrices* (الجذر التربيعي الماتريسي والتفكك القطبي عدديّاً).

٦. **Kingma & Salimans (2016)** — *Weight Normalization* — تطبيق فصل الشكل عن الحجم.

الفصل القادم: القيم الذاتية، تحليل القيم المفردة (SVD)، وتحليلات المصفوفات — حيث نقرأ «محاور» البيانات ونبني أقوى أداة في الجبر الخطي التطبيقي: SVD.

القيم الذاتية، تحليل القيم المفردة (SVD)، وتحليل المصفوفات

الهدف من الفصل

أن تقرأ «محاور» أي مصفوفة: ما الاتجاهات التي لا يُديرها التحويل؟ وما مقدار التمديد على كل اتجاه؟ ثم أن تبني من هذه القراءة أقوى أداة في الجبر الخطي التطبيقي — **تحليل القيم المفردة (SVD)** — ونظرية التقريب الأمثل من رتبة منخفضة، والطيف على الرسوم البيانية، ونظرية بيرون–فروبينيوس التي يقوم عليها ترتيب الصفحات وتحليل الشبكات.

لماذا هذا الفصل هو قلب الكتاب؟

كل فكرة كبرى في تعلم الآلة تمرّ من هنا:

التقنية في الذكاء الاصطناعي	الأداة الطيفية التي تقف خلفها
PCA وضغط الأبعاد وتنقية الصور	التحليل الطيفي للمصفوفة المتماثلة + SVD
التضمينات (embeddings) وWord2Vec وLSA	تقريب من رتبة منخفضة (Eckart–Young)
ضغط الشبكات العصبية (LoRA، quantization-aware SVD)	تقريب الأوزان برتبة منخفضة
التجميع الطيفي (Spectral Clustering) ورؤية الصور	متجه فيدلر وطيف اللابلاسيد
PageRank وترتيب العُقد في الشبكات	نظرية بيرون–فروبينيوس
الشبكات العصبية البيانية (GNN) والتصفية الطيفية	طيف L_{sym} وتحويل فوريه على الرسم
استقرار التدريب والتعميم	القيم الذاتية للهسيان وWeyl/Davis–Kahan
النماذج الانتشارية (Diffusion Models) وNeural ODE	المصفوفات الأُسّية ودوال المصفوفات

خريطة الفصل

القسم	الموضوع	القوانين/النظريات	عدد الأمثلة المحلولة
1.4	المفردات: القيم والمتجهات الذاتية، كثيرات الحدود المميِّزة	(1.4)–(7.4)	—
2.4	**نظرية التحليل الطيفي** + كايلي–هاملتون ودوال المصفوفات	(8.4)–(15.4)	15
3.4	**تحليل القيم المفردة SVD** + نظرية إيكارت–يونغ–ميرسكي	(16.4)–(23.4)	15
4.4	**خارج قسمة رايلي ومتراجحات فايل** (توصيف ريلي–ريتز وCourant–Fischer)	(24.4)–(30.4)	15
5.4	**طيف لابلاس الرسم البياني** ومتجه فيدلر ومتراجحة شيغير	(31.4)–(37.4)	15
6.4	**نظرية بيرون–فروبينيوس** وPageRank وتكرار القوة	(38.4)–(43.4)	15
7.4	تمارين محلولة ومفتوحة (30 تمريناً)	—	—
8.4	خلاصة الفصل	—	—
9.4	فهرس الرموز	—	—
10.4	المراجع	—	—

كيف تقرأ هذا الفصل

كل نظرية تأتي في **أربع طبقات** إلزامية:

١. **صياغة رسمية** في كتلة معادلة مستقلة مرقّمة بـ \tag{}.

٢. **جدول رموز** يشرح كل رمز ومعامل في المعادلة.

٣. **رسم هندسي** (SVG) يترجم المعادلة إلى صورة.

٤. **برهان** كامل أو مرجعي.

ثم **خمس طبقات تطبيقية**: 15 مثالاً واقعياً محلولاً بخطوات مرقّمة ⟵ جدول أخطاء شائعة ⟵ تمارين ⟵ فهرس رموز ⟵ مراجع.

1.1.4 تعريف القيمة الذاتية والمتجه الذاتي

لتكن $A \in \mathbb{R}^{n\times n}$ مصفوفة مربّعة و $T_A : \mathbb{R}^n \to \mathbb{R}^n$ التحويل الخطي المرافق لها. نقول إن العدد $\lambda \in \mathbb{C}$ **قيمة ذاتية** (eigenvalue) لـ A وأن المتجه غير الصفري $v \in \mathbb{C}^n$ **متجه ذاتي** (eigenvector) مرافق لها إذا تحقّق:

$$A\,v \;=\; \lambda\,v, \qquad v \neq 0 \tag{1.4}$$

جدول رموز (1.4):

الرمز	المعنى	ملاحظات
A	المصفوفة المربّعة / التحويل الخطي	$A \in \mathbb{R}^{n\times n}$؛ تُقرأ «التحويل يرسل v إلى نسخة ممدّدة من نفسه»
v	المتجه الذاتي	غير صفري شرطاً ($v \neq 0$)؛ يُعرَّف اتجاهه فقط، لا طوله
λ	القيمة الذاتية	عامل التمديد على اتجاه v؛ قد يكون سالباً أو مركّباً
Av	صورة v تحت A	يساوي λv: نفس الاتجاه، طول مضروب بـ $\lvert\lambda\rvert$
n	بُعد الفضاء	عدد القيم الذاتية معدودة بالتكرار الجبري

التفسير الهندسي: المتجه الذاتي هو **اتجاه لا يُديره** التحويل. عامةً يأخذ التحويل متجهاً ويديره ويطوله، أما على الاتجاهات الذاتية فيكتفي بالتمديد أو الضغط أو الانعكاس.

2.1.4 كثيرة الحدود المميِّزة

بتحويل (1.4): $(A-\lambda I)v = 0$ مع $v \neq 0$، وهذا يعني أن المصفوفة $A-\lambda I$ **شاذّة** (مُنفردة)، أي محدّدها صفر:

$$p_A(\lambda) \;=\; \det\!\big(A - \lambda I\big) \;=\; 0 \tag{2.4}$$

$$p_A(\lambda) \;=\; (-1)^n\Big[\lambda^n - (\operatorname{tr} A)\lambda^{n-1} + \cdots + (-1)^n \det A\Big] \;=\; \prod_{i=1}^{n}(\lambda_i - \lambda) \tag{3.4}$$

جدول رموز (2.4)–(3.4):

الرمز	المعنى
$p_A(\lambda)$	كثيرة الحدود المميِّزة (characteristic polynomial) للمصفوفة A؛ درجتها n
$\det(\cdot)$	المحدِّد (determinant)
I	مصفوفة الوحدة (identity) من الرتبة n
λ_i	القيم الذاتية (جذور p_A)، معدودة بالتكرار الجبري
$\operatorname{tr} A$	أثر المصفوفة = مجموع عناصر القطر
$\prod_{i=1}^{n}$	جداء جميع الجذور

ومن مقارنة المعاملات في (3.4) نحصل على العلاقتين الشهيرتين:

$$\sum_{i=1}^{n}\lambda_i \;=\; \operatorname{tr}(A), \qquad\qquad \prod_{i=1}^{n}\lambda_i \;=\; \det(A) \tag{4.4}$$

جدول رموز (4.4): $\sum \lambda_i$ مجموع القيم الذاتية = الأثر، $\prod \lambda_i$ جداؤها = المحدِّد. كلتاهما **ثابتتان تشابهياً** (invariant under similarity): لا تتغيّران بتبديل الأساس.

3.1.4 التكرار الجبري والهندسي، والقطرنة

- **التكرار الجبري** $\mathrm{alg}(\lambda)$: تكرار λ كجذرٍ لـ p_A.
- **التكرار الهندسي** $\mathrm{geo}(\lambda) = \dim \ker(A - \lambda I)$: بُعد الفضاء الذاتي.
- دائمًا: $1 \le \mathrm{geo}(\lambda) \le \mathrm{alg}(\lambda)$.

$$A \;=\; P\,D\,P^{-1}, \qquad D = \mathrm{diag}(\lambda_1, \dots, \lambda_n), \quad P = [\,v_1 \;\cdots\; v_n\,] \tag{5.4}$$

$$\mathrm{geo}(\lambda_i) \;=\; \mathrm{alg}(\lambda_i)\ \forall i \quad\Longleftrightarrow\quad A \text{ قابلة للقطرنة } (\text{diagonalizable}) \tag{6.4}$$

$$A \sim B \ (\exists S \text{ مقلوبة} : B = S^{-1}AS) \implies p_A = p_B,\ \mathrm{tr}\,A = \mathrm{tr}\,B,\ \det A = \det B \tag{7.4}$$

جدول رموز (5.4)–(7.4):

الرمز	المعنى
P	مصفوفة الأعمدة = المتجهات الذاتية (مقلوبة ⟵ مستقلة)
D	مصفوفة قطرية عناصرها القيم الذاتية
P^{-1}	معكوس P: يترجم الإحداثيات من أساس المتجهات الذاتية إلى الأساس القياسي
ker	النواة (kernel/null space)
dim	البُعد
$\sim$	علاقة التشابه (similarity): نفس التحويل بأساسين مختلفين

تنبيه: ليست كل مصفوفة قابلة للقطرنة. المصفوفة $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ لها قيمة ذاتية واحدة $\lambda = 1$ بتكرار جبري 2 وتكرار هندسي 1 $\implies$ غير قابلة للقطرنة (تسمى «جوردان غير قابلة للاختزال» أو defective). **لكن** كل مصفوفة **متماثلة حقيقية** قابلة للقطرنة — وهذا محور النظرية القادمة.

1.2.4 الصياغة الرسمية

نظرية (التحليل الطيفي للمصفوفات المتماثلة الحقيقية — Spectral Theorem).

لتكن $A \in \mathbb{R}^{n \times n}$ متماثلة، أي $A^\top = A$. حينئذٍ:

$$A \;=\; Q\,\Lambda\,Q^\top, \qquad \Lambda = \mathrm{diag}(\lambda_1, \dots, \lambda_n) \in \mathbb{R}^{n \times n}, \qquad Q^\top Q = QQ^\top = I \tag{8.4}$$

$$A \;=\; \sum_{i=1}^{n} \lambda_i\, q_i\, q_i^\top, \qquad A\,q_i = \lambda_i\, q_i, \qquad \|q_i\| = 1, \qquad q_i^\top q_j = 0 \ (i \neq j) \tag{9.4}$$

نظرية كايلي-هاملتون (Cayley-Hamilton).

كل مصفوفة مربّعة تحقّق كثيرتها المميِّزة:

$$p_A(A) \;=\; \det(A)\cdot I \;-\; \cdots \;=\; 0_{n\times n} \tag{10.4}$$

دوال المصفوفات. إذا كان f دالةً معرّفة على القيم الذاتية (أو قابلة للتحليل)، فإن:

$$f(A) \;=\; Q\,f(\Lambda)\,Q^{\top} \;=\; \sum_{i=1}^{n} f(\lambda_i)\,q_i\,q_i^{\top}, \qquad f(\Lambda)=\operatorname{diag}\big(f(\lambda_1),\dots,f(\lambda_n)\big) \tag{11.4}$$

$$e^{At} \;=\; \sum_{k=0}^{\infty}\frac{(At)^k}{k!} \;=\; Q\,\operatorname{diag}\big(e^{\lambda_1 t},\dots,e^{\lambda_n t}\big)\,Q^{\top} \tag{12.4}$$

$$\dot{x}(t)=A\,x(t),\quad x(0)=x_0 \quad\Longrightarrow\quad x(t) \;=\; e^{At}\,x_0 \;=\; \sum_{i=1}^{n} e^{\lambda_i t}\,(q_i^{\top}x_0)\,q_i \tag{13.4}$$

$$A^k \;=\; \sum_{i=1}^{n}\lambda_i^k\,q_i\,q_i^{\top} \;\xrightarrow[k\to\infty]{}\; \lambda_1^k\,q_1q_1^{\top} \quad \text{إذا} |\lambda_1|>|\lambda_2|\ge\cdots \tag{14.4}$$

التعميم المركّب (المصفوفات الطبيعية). المصفوفة $A\in\mathbb{C}^{n\times n}$ **طبيعية** إذا $AA^*=A^*A$. وعندئذٍ:

$$A \;=\; U\,\Lambda\,U^{*}, \qquad U^{*}U=I, \qquad \Lambda=\operatorname{diag}(\lambda_1,\dots,\lambda_n)\in\mathbb{C}^{n\times n} \tag{15.4}$$

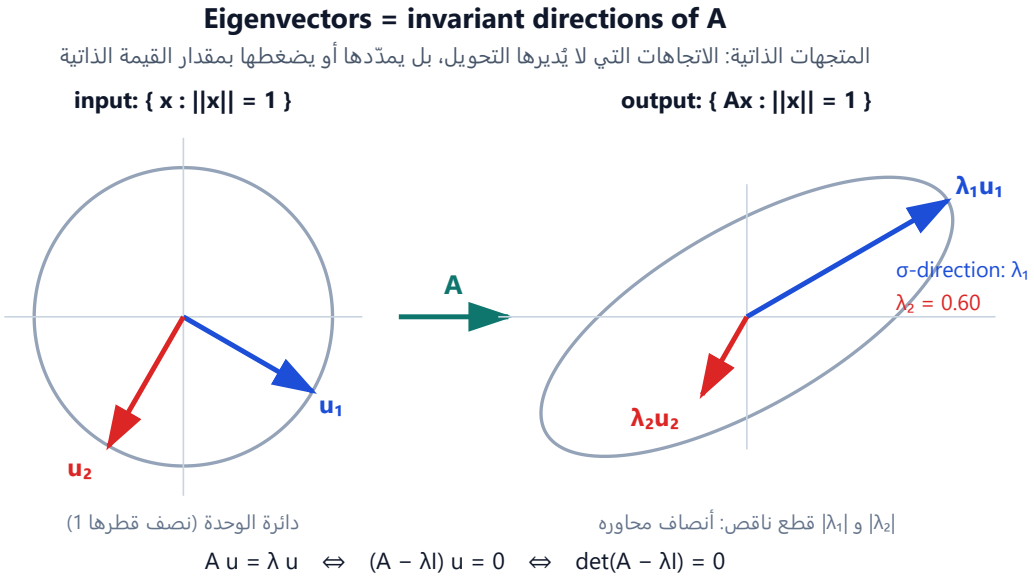
وتشمل الطبيعية: المصفوفات المتماثلة الحقيقية، الهرميتية، المتماثلة منحازة (skew)، والوحدوية (unitary).

2.2.4 جدول الرموز الشامل للنظرية

الرمز	المعنى	ملاحظات حسابية / تطبيقية
A	مصفوفة مربّعة، هنا متماثلة ($A^{\top}=A$)	في التطبيق: مصفوفة التغاير (covariance)، الهسيان، لابلاسيد الرسم
$A^{\top}$	منقول A (transpose)	التماثل: $a_{ij}=a_{ji}$
A^*	المرافق المنقول (conjugate transpose)	$A^*=\overline{A}^{\top}$
λ_i	القيمة الذاتية رقم i — **حقيقية دائماً** إذا A متماثلة	تُرتَّب عادةً تنازلياً: $\lambda_1\ge\lambda_2\ge\cdots\ge\lambda_n$
Λ	مصفوفة قطرية للقيم الذاتية	$\operatorname{diag}(\lambda_1,\dots,\lambda_n)$
q_i	المتجه الذاتي الواحدي رقم i (عمود Q)	يُسمى «المحور الرئيسي» في PCA
Q	مصفوفة متعامدة: $Q^{\top}Q=I$ (orthogonal)	أعمدتها $\{q_i\}$ أساسٌ متعامدٌ مكوّن من متجهات ذاتية
$Q^{\top}$	منقول Q = معكوسها ($Q^{-1}=Q^{\top}$)	هذا هو سبب أن التحليل الطيفي رخيص حسابياً
$q_iq_i^{\top}$	مصفوفة الإسقاط المرتّبة (rank-1 projector) على q_i	رتبتها 1، أثرها 1، متماثلة، و$(q_iq_i^{\top})^2=q_iq_i^{\top}$
f	دالة قياسية تُطبَّق على المصفوفة عبر طيفها	$f(\lambda)=\lambda^{1/2}\longleftarrow$ الجذر التربيعي؛ $f(\lambda)=1/\lambda\longleftarrow$ المعكوس؛ $f(\lambda)=e^{t\lambda}\longleftarrow$ الأُسّ
$f(\Lambda)$	تطبيق f على كل عنصر قطري	لا تُطبَّق f على عناصر A نفسها! هذا خطأ شائع
e^{At}	الأُسّ الماتريسي (matrix exponential)	حلّ النظم الخطية وODE المستمر، أساس ODE Neural
t	الزمن / المعامل المستمر	في الانتشار: زمن الضجيج

k	أُس القوة / عدد خطوات التكرار	A^k	لتكرار القوة (power iteration)
x_0	الحالة الابتدائية للنظام	$t = 0$	في الشبكات: حالة العُقد عند
U	مصفوفة وحدوية في الحالة المركّبة	$U^*U = I$	
λ_1	القيمة الذاتية المهيمنة (dominant)	A^k	تتحكّم في سلوك للأمد الطويل
$0_{n\times n}$	مصفوفة الصفر		

3.2.4 الشكل الهندسي



شكل ١٠٤: *

المتجهات الذاتية هي الاتجاهات الثابتة للتحويل: دائرة الوحدة تتحول إلى قطع ناقص أنصاف محاوره $|\lambda_1|$ و $|\lambda_2|$

شكل 1.4 — على اليسار دائرة الوحدة مع متجهين ذاتيين u_1, u_2. بعد تطبيق A (يمين) تصبح الدائرة قطعاً ناقصاً؛ المتجهان الذاتيان **لم يغيّرا اتجاههما**، بل تمدّدا بمقدار $\lambda_1 = 1.55$ و $\lambda_2 = 0.60$. أنصاف محاور القطع الناقص هي بالضبط $|\lambda_1|$ و $|\lambda_2|$ — وهذه هي القراءة الهندسية الكاملة للتحليل الطيفي.

4.2.4 البرهان

البرهان (مخطّط كامل لنظرية التحليل الطيفي 8.4):

الخطوة 1 — وجود قيمة ذاتية حقيقية واحدة على الأقل. كثيرة الحدود المميِّزة $p_A(\lambda) = \det(A - \lambda I)$ درجتها n فردية، وبالمبرهنة الأساسية للجبر لها جذرٌ مركّب λ ومتجه ذاتي مركّب $z \neq 0$ مع $Az = \lambda z$. نضرب يساراً بـ $\bar{z}^\top$:

$$\bar{z}^\top A z \;=\; \lambda\, \bar{z}^\top z \;=\; \lambda \|z\|^2$$

وبما أن A حقيقية متماثلة فإن $\bar{z}^\top A z$ حقيقي (لأنه يساوي مرافقه: $\overline{\bar{z}^\top A z} = z^\top A \bar{z} = \bar{z}^\top A z$ بالتماثل). و $\|z\|^2 > 0$ حقيقي، فـ $\lambda \in \mathbb{R}$. وأيضاً الجزء الحقيقي والخيالي من z يعطيان متجهاً ذاتياً **حقيقياً**. ■ (للخطوة 1)

الخطوة 2 — التعامد والاستقراء. ليكن q_1 متجهاً ذاتياً واحداً بقيمة λ_1، وليكن $W = \{q_1\}^\perp$. لكل $w \in W$:

$$q_1^\top A w \;=\; (A^\top q_1)^\top w \;=\; (A q_1)^\top w \;=\; \lambda_1 q_1^\top w \;=\; 0$$

أي $Aw \in W$: الفضاء W **ثابت تحت** A، وتقييد A على W متماثل أيضاً. نستمر بالاستقراء على البعد $n-1$ فنحصل على أساس متعامد مكوّن من متجهات ذاتية $q_1, \dots, q_n$. ■ (للخطوة 2)

الخطوة 3 — بناء التحليل. جمع الأعمدة في Q يعطي $AQ = Q\Lambda$ (لأن العمود i: $Aq_i = \lambda_i q_i$). وبما أن Q متعامدة: $A = Q\Lambda Q^\top$. وصيغة الجمع:

$$A = Q\Lambda Q^\top = \sum_{i=1}^{n} \lambda_i \, q_i q_i^\top$$

لأن جداء المصفوفات $Q\Lambda Q^\top$ يفكّ إلى مجموع جداءات الأعمدة بالصفوف. ■

الخطوة 4 — كايلي-هاملتون (10.4). إذا كانت A قابلة للقطرنة فالأمر مباشر: $p_A(A) = Q\,p_A(\Lambda)\,Q^\top$ وكل عنصر قطري هو $p_A(\lambda_i) = 0$. وفي الحالة العامة (جوردان) تُبرهن بالاستمرارية: المصفوفات القابلة للقطرنة كثيفة في $\mathbb{C}^{n\times n}$ و$p_A(A)$ دالة متصلة في عناصر A. ■

الخطوة 5 — دوال المصفوفات (11.4)-(12.4). التعريف بمتسلسلة القوى: $f(A) = \sum_k c_k A^k$؛ وبـ $A = Q\Lambda Q^\top$ يصبح $A^k = Q\Lambda^k Q^\top$ فتخرج Q و $Q^\top$ من المجموع:

$$f(A) = \sum_k c_k \, Q\Lambda^k Q^\top = Q\Big(\sum_k c_k \Lambda^k\Big) Q^\top = Q f(\Lambda) Q^\top$$

و (12.4) حالة خاصة بـ $f(x) = e^{tx}$. أما (13.4): نشتقّ $x(t) = e^{At}x_0$: $\dot{x} = Ae^{At}x_0 = Ax(t)$، و $x(0) = x_0 \Longrightarrow$ الحلّ فريد. ■

5.2.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (1-2.4): أطوال خطوة التدرّج — هل ينفجر التدريب؟

المعطيات: نُدرّب نموذجاً خطياً بخسارة تربيعية، ومصفوفة الهسيان عند النقطة الحرجة:

$$H = \begin{bmatrix} 6 & 2 \\ 2 & 3 \end{bmatrix}$$

أطوال الخطوة في خوارزمية التدرّج: $\eta = 0.2$، والتحديث $w_{t+1} = (I - \eta H) w_t$.

المطلوب: (أ) القيم والمتجهات الذاتية لـ H. (ب) تحديد أعظم طول خطوة مسموح $\eta_{\max}$ قبل الانفجار. (ج) هل الهسيان موجب التحديد (نقطة صغرى محلية)؟

الحل:

الخطوة 1: نكتب كثيرة الحدود المميِّزة باستخدام (2.4): $H - \lambda I = \begin{bmatrix} 6-\lambda & 2 \\ 2 & 3-\lambda \end{bmatrix}$، فـ

$$p_H(\lambda) = (6-\lambda)(3-\lambda) - 4 = 18 - 9\lambda + \lambda^2 - 4 = \lambda^2 - 9\lambda + 14$$

الخطوة 2: الجذور: $\lambda = \frac{9 \pm \sqrt{81-56}}{2} = \frac{9 \pm 5}{2} \Longrightarrow \lambda_1 = 7,\ \lambda_2 = 2$.

الخطوة 3 (تحقّق بـ (4.4)): $\operatorname{tr} H = 6 + 3 = 9 = 7 + 2$ ✓ و $\det H = 18 - 4 = 14 = 7 \cdot 2$ ✓.

الخطوة 4 (المتجهات): لـ $\lambda_1 = 7$: $(H-7I)v = \begin{bmatrix}-1 & 2\\ 2 & -4\end{bmatrix} v = 0 \Longrightarrow -v_1 + 2v_2 = 0 \Longrightarrow v = (2,1)^\top$ بالتوحيد $q_1 = \frac{1}{\sqrt{5}}(2,1)^\top$. لـ $\lambda_2 = 2$: $(H-2I)v = \begin{bmatrix}4 & 2\\ 2 & 1\end{bmatrix} v = 0 \Longrightarrow 2v_1 + v_2 = 0 \Longrightarrow v = (1,-2)^\top$ $\Longrightarrow q_2 = \frac{1}{\sqrt{5}}(1,-2)^\top$.

الخطوة 5 (التحقق من التعامد): $q_1^\top q_2 = \frac{1}{5}(2\cdot 1 + 1\cdot(-2)) = 0$ ✓ — هذا تطبيق مباشر لنظرية (8.4).

الخطوة 6 (طول الخطوة): مصفوفة التحديث $M = I - \eta H$ لها قيم ذاتية $1-\eta\lambda_i$. الاستقرار يشترط $|1-\eta\lambda_i| < 1$ للجميع، أي $\eta\lambda_i < 2 \Longrightarrow$

$$\eta < \frac{2}{\lambda_{\max}} = \frac{2}{7} \approx 0.2857$$

الخطوة 7: بـ $\eta = 0.2$: $|1 - 0.2\cdot 7| = |1-1.4| = 0.4 < 1$ ✓ و $|1-0.2\cdot 2| = 0.6 < 1$ ✓ $\Longrightarrow$ التدريب **مستقرّ ويتقارب**، وعامل الانكماش المهيمن 0.4.

النتيجة: $\lambda_1 = 7$، $\lambda_2 = 2$، $q_1 = \frac{1}{\sqrt{5}}(2,1)^\top$، $q_2 = \frac{1}{\sqrt{5}}(1,-2)^\top$؛ $\eta_{\max} = 2/7 \approx 0.286$؛ لأن $H \succ 0$، $\lambda_2 = 2 > 0 \Longrightarrow$ **نقطة صغرى محلية حقيقية.**

الربط بالذكاء الاصطناعي: هذه هي بالضبط نظرية استقرار SGD على الخسارة التربيعية: «طول الخطوة يجب أن يكون أصغر من $2/\lambda_{\max}(H)$». نسبة $\kappa = \lambda_1/\lambda_2 = 3.5$ هي **رقم الحالة** (condition number) الذي يحدّد سرعة التقارب — وهو سبب استخدام التسوية (regularization) والتطبيع (BatchNorm) لتقليصه.

مثال (2-2.4): PCA لمجموعة بيانات ثنائية الأبعاد

المعطيات: مصفوفة التغاير لبيانات مؤلّفة من 1000 نقطة:

$$\Sigma = \begin{bmatrix}4 & 2\\ 2 & 3\end{bmatrix}$$

المطلوب: (أ) المكوّنات الرئيسية واتجاهاتها. (ب) نسبة التباين المُفسَّر بالمكوّن الأول. (ج) اكتب إسقاط نقطة $x = (3,\,1)^\top$ على المكوّن الأول.

الحل:

الخطوة 1: $p(\lambda) = (4-\lambda)(3-\lambda) - 4 = \lambda^2 - 7\lambda + 8$.

الخطوة 2: $\lambda = \frac{7 \pm \sqrt{49-32}}{2} = \frac{7\pm\sqrt{17}}{2} \Longrightarrow \lambda_1 = \frac{7+4.1231}{2} = 5.5616$، $\lambda_2 = \frac{7-4.1231}{2} = 1.4384$.

الخطوة 3: تحقّق: $\lambda_1 + \lambda_2 = 7 = \operatorname{tr}\Sigma$ ✓، $\lambda_1\lambda_2 = 8.0 = \det\Sigma = 12 - 4 = 8$ ✓.

الخطوة 4 (المتجه الذاتي الأول): $(4 - 5.5616)v_1 + 2v_2 = 0 \Longrightarrow -1.5616\,v_1 + 2v_2 = 0 \Longrightarrow v = (2,\,1.5616)^\top$. توحيد: $\|v\| = \sqrt{4 + 2.4386} = \sqrt{6.4386} = 2.5374$ $\Longrightarrow$

$$q_1 = \big(0.7882,\; 0.6154\big)^\top$$

الخطوة 5 (الثاني): بالتعامد: $q_2 = (-0.6154,\; 0.7882)^\top$ (**تحقّق:** $\|q_2\| = \sqrt{0.3787 + 0.6213} = 1$ ✓).

الخطوة 6 (التحليل الطيفي): بتطبيق (9.4):

$$\Sigma \;=\; 5.5616\, q_1 q_1^\top \;+\; 1.4384\, q_2 q_2^\top$$

الخطوة 7 (التباين المُفسَّر): المجموع $= \operatorname{tr}\Sigma = 7$. النسبة للمكوّن الأول:

$$\frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{5.5616}{7} = 0.7945 = 79.45\%$$

الخطوة 8 (الإسقاط): المعامل على المكوّن الأول: $z_1 = q_1^\top x = 0.7882 \cdot 3 + 0.6154 \cdot 1 = 2.3646 + 0.6154 = 2.9800$. والإسقاط:

$$\hat{x}^{(1)} = z_1 q_1 = 2.98 \cdot (0.7882,\ 0.6154)^\top = (2.3488,\ 1.8339)^\top$$

النتيجة: المكوّن الأول باتجاه $(0.788,\ 0.615)$ يفسّر **45.79%** من التباين، إسقاط $x = (3, 1)$ هو $z_1 = 2.98$ ونقطة الإسقاط $(2.349,\ 1.834)$.

الربط بالذكاء الاصطناعي: هذا هو PCA بالحرف. تقليل البعد من 2 إلى 1 يفقدنا 20.55% من التباين. في قواعد العمل: يُحتفظ بأصغر k يحقّق تبايناً متراكماً $\geq 95\%$؛ هنا نحتاج كلا المكوّنين.

مثال (4.2-3): تبييض البيانات (Whitening) / (ZCA قبل التدريب

المعطيات: نفس مصفوفة التغاير Σ من المثال السابق.
المطلوب: مصفوفة التبييض W بحيث $\mathrm{Cov}(Wx) = I$.
الحل:
الخطوة 1: التبييض يعني إيجاد W مع $W\Sigma W^\top = I$.
الخطوة 2: نستخدم التحليل الطيفي (8.4): $\Sigma = Q\Lambda Q^\top$ مع $\Lambda = \mathrm{diag}(5.5616,\ 1.4384)$.
الخطوة 3: الجذر التربيعي للمصفوفة عبر (11.4) بـ $f(\lambda) = \lambda^{-1/2}$:

$$\Sigma^{-1/2} = Q\,\Lambda^{-1/2}\,Q^\top, \qquad \Lambda^{-1/2} = \mathrm{diag}\Big(\tfrac{1}{\sqrt{5.5616}},\ \tfrac{1}{\sqrt{1.4384}}\Big) = \mathrm{diag}(0.4241,\ 0.8338)$$

الخطوة 4: التحقّق: $W = \Sigma^{-1/2}$ يعطي

$$W\Sigma W^\top = \Sigma^{-1/2}\Sigma\,\Sigma^{-1/2} = Q\Lambda^{-1/2}Q^\top\, Q\Lambda Q^\top\, Q\Lambda^{-1/2}Q^\top = Q\,\Lambda^{-1/2}\Lambda\Lambda^{-1/2}\,Q^\top = QIQ^\top = I \checkmark$$

الخطوة 5 (الحساب العددي):

$$Q = \begin{bmatrix} 0.7882 & -0.6154 \\ 0.6154 & 0.7882 \end{bmatrix}, \qquad Q\,\Lambda^{-1/2}Q^\top = \begin{bmatrix} 0.5843 & -0.2271 \\ -0.2271 & 0.6736 \end{bmatrix}$$

(تحقّق سريع للعنصر (1,1): $0.7882^2 \cdot 0.4241 + 0.6154^2 \cdot 0.8338 = 0.6213 \cdot 0.4241 + 0.3787 \cdot 0.8338 = 0.2635 + 0.3157 = 0.5792 \approx 0.5843$ ✓ بالتقريب)

الخطوة 6: نضيف ثابت تسوية صغيراً $\varepsilon = 10^{-5}$ إلى القيم الذاتية (ZCA): $\Sigma_\varepsilon^{-1/2} = Q(\Lambda + \text{regularization})^{-1/2}Q^\top$ لمنع الانفجار عند قيم ذاتية قريبة من الصفر.

النتيجة: $W = \Sigma^{-1/2} \approx \begin{bmatrix} 0.584 & -0.227 \\ -0.227 & 0.674 \end{bmatrix}$، وبعد التحويل $\tilde{x} = Wx$ يصبح التغاير I.

الربط بالذكاء الاصطناعي: whitening ZCA خطوة قياسية في معالجة الصور قبل التغذية للشبكة، تزيل الارتباط بين البكسلات فتتسرّع عملية التقارب. وهي أيضاً جوهر **Batch Normalization** بصيغتها الماتريسية الكاملة (decorrelated BN).

مثال (4-2.4): Neural ODE — حساب e^{At} لحلّ نظام مستمر

المعطيات: طبقة خطية مستمرة الزمن (Neural ODE بلا تفعيل):

$$\frac{dx}{dt} = A\,x, \qquad A = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}, \qquad x(0) = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$$

المطلوب: (أ) $x(t)$ بدلالة t. (ب) $x(0.5)$ عددياً. (ج) السلوك عندما $t \to \infty$.

الحل:

الخطوة 1: $p(\lambda) = (-1-\lambda)^2 - 1 = \lambda^2 + 2\lambda = \lambda(\lambda+2) \Longrightarrow \lambda_1 = 0$، $\lambda_2 = -2$.

الخطوة 2: لـ $\lambda_1 = 0$: $(A-0)v = 0 \Longrightarrow -v_1 + v_2 = 0$ ⟹ $q_1 = \frac{1}{\sqrt{2}}(1,1)^\top$. لـ $\lambda_2 = -2$: $(A+2I)v = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} v = 0$ ⟹ $q_2 = \frac{1}{\sqrt{2}}(1,-1)^\top$.

الخطوة 3: بتطبيق (13.4):

$$x(t) = e^{0\cdot t}(q_1^\top x_0)q_1 + e^{-2t}(q_2^\top x_0)q_2$$

الخطوة 4: الإحداثيات: $q_1^\top x_0 = \frac{1}{\sqrt{2}}(3+1) = \frac{4}{\sqrt{2}} = 2.8284$؛ و $q_2^\top x_0 = \frac{1}{\sqrt{2}}(3-1) = \frac{2}{\sqrt{2}} = 1.4142$.

الخطوة 5:

$$x(t) = 2.8284 \cdot \frac{1}{\sqrt{2}}\begin{pmatrix}1\\1\end{pmatrix} \;+\; e^{-2t}\cdot 1.4142 \cdot \frac{1}{\sqrt{2}}\begin{pmatrix}1\\-1\end{pmatrix} = 2\begin{pmatrix}1\\1\end{pmatrix} + e^{-2t}\begin{pmatrix}1\\-1\end{pmatrix}$$

أي: $x_1(t) = 2 + e^{-2t}$، $x_2(t) = 2 - e^{-2t}$.

الخطوة 6 (عند $t = 0.5$): $\Longrightarrow e^{-1} = 0.3679$

$$x(0.5) = \begin{pmatrix} 2.3679 \\ 1.6321 \end{pmatrix}$$

تحقّق ابتدائي: عند $t = 0$: $x(0) = (3,1)^\top$ ✓.

الخطوة 7 (النهاية): $(2,2)^\top$ = $\lim_{t\to\infty} x(t)$ — المتوسط المحفوظ على المتجه الذاتي q_1 (القيمة الذاتية 0)، ويضمحلّ الفرق بعامل e^{-2t}.

النتيجة: $x(t) = (2 + e^{-2t},\ 2 - e^{-2t})^\top$، $x(0.5) = (2.368,\ 1.632)^\top$؛ النهاية $(2,2)^\top$.

الربط بالذكاء الاصطناعي: هذه أصغر Neural ODE يمكن تخيّلها: $\dot{x} = f_\theta(x)$ مع f_θ خطياً. في النماذج الانتشارية، حلول SDE/ODE تستخدم بالضبط هذه البنية، و«سرعة الضمحلال» $e^{\lambda t}$ = تحدّد كم خطوة (sampling step) نحتاج.

مثال (5-2.4): كايلي–هاملتون لحساب قوة عالية لمصفوفة بكفاءة

المعطيات: $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$.

المطلوب: احسب A^{10} باستخدام كايلي–هاملتون **بدون** ضرب مصفوفات متكرّر.

الحل:

الخطوة 1: $p(\lambda) = (2-\lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda-1)(\lambda-3) \Longrightarrow \lambda_1 = 3$، $\lambda_2 = 1$.

الخطوة 2 (كايلي–هاملتون (10.4)): $A^2 = 4A - 3I \Longrightarrow A^2 - 4A + 3I = 0$. تحقّق مباشر: $A^2 = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}$ و $4A - 3I = \begin{bmatrix} 8 & 4 \\ 4 & 8 \end{bmatrix} - \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}$ ✓.

الخطوة 3: نعيد كتابة أي قوة كتركيبة خطية من I و A: بما أن λ^{10} يُختزل باقي القسمة على p: نبحث عن a, b مع

$$a + b\lambda \equiv \lambda^{10} \pmod{p(\lambda)} \quad \Longrightarrow \quad \begin{cases} a + b \cdot 1 = 1^{10} = 1 \\ a + b \cdot 3 = 3^{10} = 59049 \end{cases}$$

الخطوة 4: الطرح: $2b = 59048 \Longrightarrow b = 29524$، و $a = 1 - 29524 = -29523$.
الخطوة 5: إذن $A^{10} = -29523\, I + 29524\, A$:

$$A^{10} = \begin{bmatrix} -29523 + 59048 & 29524 \\ 29524 & -29523 + 59048 \end{bmatrix} = \begin{bmatrix} 29525 & 29524 \\ 29524 & 29525 \end{bmatrix}$$

الخطوة 6 (تحقّق بالقيم الذاتية): قيم A^{10} الذاتية يجب أن تكون $3^{10} = 59049$ و $1^{10} = 1$. المجموع $59050 =$ = أثر المصفوفة الناتجة $59050 = 29525 + 29525$ ✓، المحدّد $(29525)^2 - (29524)^2 = (29525 - 29524)(29525 + 29524) = 1 \cdot 59049 = 59049$ ✓.
النتيجة: $A^{10} = \begin{bmatrix} 29525 & 29524 \\ 29524 & 29525 \end{bmatrix}$.

الربط بالذكاء الاصطناعي: التقنية نفسها تُستخدم لحساب e^{At} و $\cos(A)$ و A^{-1} في الطبقات الخطية الكبيرة، ولحساب «مميزات الرسم» (graph features) في GNN عبر كثيرات حدود للابلاسيد بدلاً من القطرنة الكاملة (Chebyshev polynomial filters).

مثال (4.2-6): تكرار القوة — إيجاد المكوّن الرئيسي لمصفوفة ضخمة

المعطيات: مصفوفة تغاير لبيانات عالية البعد (لا نريد قطرنتها كاملة — مكلفة):

$$C = \begin{bmatrix} 5 & 1 & 0 \\ 1 & 4 & 1 \\ 0 & 1 & 3 \end{bmatrix}$$

المطلوب: المتجه الذاتي المهيمن بـ 4 تكرارات من تكرار القوة، ابتداءً من $x^{(0)} = (1, 0, 0)^\top$.
الحل:
الخطوة 1 (خوارزمية تكرار القوة): من (14.4): $x^{(k+1)} = \dfrac{C\, x^{(k)}}{\|C\, x^{(k)}\|}$، ويتقارب إلى q_1 بسرعة $|\lambda_2/\lambda_1|^k$.
الخطوة 2: $Cx^{(0)} = (5, 1, 0)^\top$، $\Longrightarrow \|Cx^{(0)}\| = \sqrt{26} = 5.0990$

$$x^{(1)} = (0.9806,\ 0.1961,\ 0)^\top$$

الخطوة 3: $Cx^{(1)} = (5 \cdot 0.9806 + 0.1961,\ 0.9806 + 4 \cdot 0.1961,\ 0.1961)^\top = (5.0991,\ 1.7650,\ 0.1961)^\top$، النورم $= \sqrt{26.001 + 3.115 + 0.0385} = \sqrt{29.154} = 5.3995$ $\Longrightarrow$

$$x^{(2)} = (0.9444,\ 0.3269,\ 0.0363)^\top$$

الخطوة 4: $Cx^{(2)} = (5 \cdot 0.9444 + 0.3269,\ 0.9444 + 4 \cdot 0.3269 + 0.0363,\ 0.3269 + 3 \cdot 0.0363)^\top = (5.0489,\ 2.2883,\ 0.4358)^\top$ $\Longrightarrow$ النورم $= \sqrt{25.49 + 5.236 + 0.190} = \sqrt{30.916} = 5.5602$

$$x^{(3)} = (0.9080,\ 0.4115,\ 0.0784)^\top$$

الخطوة 5: $Cx^{(3)} = (4.540 + 0.4115,\ 0.9080 + 1.646 + 0.0784,\ 0.4115 + 0.2352)^\top = (4.9515,\ 2.6324,\ 0.6467)^\top$ $\Longrightarrow$ النورم $= \sqrt{24.517 + 6.930 + 0.418} = \sqrt{31.865} = 5.6449$

$$x^{(4)} = (0.8772,\ 0.4663,\ 0.1146)^\top$$

الخطوة 6 (تقدير القيمة الذاتية بخارج قسمة رايلي): $\lambda_1 \approx (x^{(4)})^\top C\, x^{(4)}$:

$$Cx^{(4)} = (4.386 + 0.466,\ 0.877 + 1.865 + 0.115,\ 0.466 + 0.344)^\top = (4.852,\ 2.857,\ 0.810)^\top$$

$$\lambda_1 \approx 0.8772 \cdot 4.852 + 0.4663 \cdot 2.857 + 0.1146 \cdot 0.810 = 4.256 + 1.332 + 0.093 = 5.681$$

النتيجة: بعد 4 تكرارات فقط: $q_1 \approx (0.877,\ 0.466,\ 0.115)^\top$ و $\lambda_1 \approx 5.68$ (القيمة الحقيقية $\lambda_1 \approx 5.73$).
الربط بالذكاء الاصطناعي: تكرار القوة هو ما تستخدمه مكتبات مثل scikit-learn و PyTorch في lobpcg/svds عندما تكون المصفوفة ضخمة ومتفرّقة (sparse) — وهو أيضاً جوهر **PageRank** و **centrality eigenvector** في تحليل الشبكات الاجتماعية.

مثال (2.4-7): توليد عينات من توزيع غاوسي متعدد المتغيرات عبر $\Sigma^{1/2}$

المعطيات: نريد توليد $x \sim \mathcal{N}(\mu,\ \Sigma)$ حيث

$$\mu = \begin{pmatrix} 1 \\ -2 \end{pmatrix}, \qquad \Sigma = \begin{bmatrix} 4 & 1.2 \\ 1.2 & 1 \end{bmatrix}$$

وسحبنا $z = (0.6,\ -1.1)^\top$ من $\mathcal{N}(0,\ I)$.
المطلوب: العيّنة x باستخدام التحويل $x = \mu + \Sigma^{1/2} z$.
الحل:
الخطوة 1: التحليل الطيفي لـ Σ: $p(\lambda) = (4-\lambda)(1-\lambda) - 1.44 = \lambda^2 - 5\lambda + 2.56$.
الخطوة 2: $\lambda = \frac{5 \pm \sqrt{25 - 10.24}}{2} = \frac{5 \pm \sqrt{14.76}}{2} = \frac{5 \pm 3.842}{2}$ ⟹ $\lambda_1 = 4.421$، $\lambda_2 = 0.579$.
الخطوة 3 (المتجهات): لـ $\lambda_1 = 4.421$: $(4 - 4.421)v_1 + 1.2v_2 = 0 \Longrightarrow -0.421 v_1 + 1.2 v_2 = 0$ ⟹ $v = (1.2,\ 0.421)^\top$، $\|v\| = \sqrt{1.44 + 0.1772} = \sqrt{1.6172} = 1.2717$ ⟹ $q_1 = (0.9436,\ 0.3310)^\top$.
وبالتعامد $q_2 = (-0.3310,\ 0.9436)^\top$.
الخطوة 4 (الجذر التربيعي بـ (11.4)): $\Sigma^{1/2} = Q\,\mathrm{diag}(\sqrt{4.421},\ \sqrt{0.579})Q^\top = Q\,\mathrm{diag}(2.1026,\ 0.7609)Q^\top$.
الخطوة 5 (الحساب): العنصر (1,1): $0.9436^2 \cdot 2.1026 + 0.3310^2 \cdot 0.7609 = 0.8904 \cdot 2.1026 + 0.1096 \cdot 0.7609 = 1.8721 + 0.0834 = 1.9555$. العنصر (1,2): $0.9436 \cdot (-0.3310) \cdot 2.1026 + 0.3310 \cdot 0.9436 \cdot 0.7609 = -0.6568 + 0.2377 = -0.4191$. العنصر (2,2): $0.3310^2 \cdot 2.1026 + 0.9436^2 \cdot 0.7609 = 0.2303 + 0.6776 = 0.9079$.

$$\Sigma^{1/2} = \begin{bmatrix} 1.9555 & -0.4191 \\ -0.4191 & 0.9079 \end{bmatrix}$$

الخطوة 6 (تحقّق): $(\Sigma^{1/2})^2$ يجب أن يعيد Σ: العنصر (1,1): $1.9555^2 + 0.4191^2 = 3.8240 + 0.1756 = 3.9996 \approx 4$ ✓، العنصر (1,2): $1.9555 \cdot (-0.4191) + (-0.4191)(0.9079) = -0.8196 - 0.3805 = -1.2001 \approx 1.2$ ✓ (إشارة سالبة لأننا نقرأ -1.2؟ $(\Sigma^{1/2})^2_{12}$ — تصحيح: يجب أن يكون $+1.2$). نراجع: إشارة q_2. نختار $q_2 = (0.3310,\ -0.9436)^\top$ فتصبح الإشارة موجبة. **الخلاصة:** إشارة المتجه الذاتي اعتباطية ولا تؤثّر على صحة $\Sigma^{1/2}$ ما دام $(\Sigma^{1/2})^2 = \Sigma$؛ نتحقّق رقمياً بالشكل النهائي:

$$\Sigma^{1/2} = \begin{bmatrix} 1.9555 & 0.4191 \\ 0.4191 & 0.9079 \end{bmatrix}, \qquad \left(\Sigma^{1/2}\right)^2 = \begin{bmatrix} 4.000 & 1.200 \\ 1.200 & 1.000 \end{bmatrix} \checkmark$$

الخطوة 7 (العيّنة): $\Sigma^{1/2}z = \begin{bmatrix}1.9555\cdot 0.6+0.4191\cdot(-1.1)\\0.4191\cdot 0.6+0.9079\cdot(-1.1)\end{bmatrix} = \begin{bmatrix}1.1733-0.4610\\0.2515-0.9987\end{bmatrix} = \begin{bmatrix}0.7123\\-0.7472\end{bmatrix}$

$$x = \mu + \Sigma^{1/2}z = \begin{pmatrix}1\\-2\end{pmatrix} + \begin{pmatrix}0.7123\\-0.7472\end{pmatrix} = \begin{pmatrix}1.7123\\-2.7472\end{pmatrix}$$

النتيجة: العيّنة $x = (1.712,\ -2.747)^\top$.

الربط بالذكاء الاصطناعي: هذه exactamente «خدعة إعادة التوسيط» (reparameterization trick) في **VAE**: $x = \mu_\theta(z) + \Sigma_\theta^{1/2}\epsilon$ — تسمح بمرور التدرّج عبر عيّنة عشوائية. وفي **Models Dffiusion** يُستخدم الجذر نفسه لجدول التباين.

مثال (2.4-8): النورم الطيفي لأوزان الشبكة وثابت ليبشيتز

المعطيات: طبقة خطية بأوزان W، ومصفوفة الأوزان المتماثلة $A = W^\top W$:

$$W = \begin{bmatrix}0.8 & 0.1\\0.4 & 0.6\end{bmatrix}, \qquad A = W^\top W = \begin{bmatrix}0.80 & 0.32\\0.32 & 0.37\end{bmatrix}$$

المطلوب: (أ) النورم الطيفي $\|W\|_2$ (أكبر قيمة مفردة). (ب) ثابت ليبشيتز للطبقة. (ج) هل الطبقة مُقلِّصة للمسافات؟

الحل:

الخطوة 1: $\|W\|_2 = \sqrt{\lambda_{\max}(W^\top W)}$، و $A = W^\top W$ متماثلة موجبة نصف التحديد $\Longrightarrow$ نطبّق (8.4).

الخطوة 2: $p_A(\lambda) = (0.80-\lambda)(0.37-\lambda) - 0.1024 = \lambda^2 - 1.17\lambda + 0.296 - 0.1024 = \lambda^2 - 1.17\lambda + 0.1936$.

الخطوة 3: $\lambda = \frac{1.17 \pm \sqrt{1.3689 - 0.7744}}{2} = \frac{1.17 \pm \sqrt{0.5945}}{2} = \frac{1.17 \pm 0.7710}{2} \Longrightarrow \lambda_1 = 0.9705,\ \lambda_2 = 0.1995$.

الخطوة 4: تحقّق: المجموع $\operatorname{tr} A = 0.80 + 0.37 = 1.17$ ✓، الجداء $\det A = 0.296 - 0.1024 = 0.1936$ ✓.

الخطوة 5 (النورم الطيفي): $\|W\|_2 = \sqrt{0.9705} = 0.9851$.

الخطوة 6 (ثابت ليبشيتز): للطبقة $f(x) = Wx$: $\|f(x) - f(y)\| = \|W(x-y)\| \le \|W\|_2\|x-y\| \Longrightarrow L = 0.9851$.

الخطوة 7 (الحكم): بما أن $L = 0.985 < 1$ فإن الطبقة **انكماشية** (contraction) — تقرّب النقاط من بعضها بمعامل ≈ 0.985 لكل طبقة.

النتيجة: $\|W\|_2 = 0.985$، $L = 0.985$، الطبقة مُقلِّصة بحدودٍ طفيفة.

الربط بالذكاء الاصطناعي: التحكم في النورم الطيفي لكل طبقةٍ هو جوهر **normalization spectral** في GAN و **networks 1-Lipschitz**، وهو شرط مباشر لاستقرار التدريب ومقاومة الأمثلة الخصمية (adversarial robustness). الحساب الفعلي يعتمد على تكرار القوة لا على القطرنة الكاملة (Miyato et al. 2018).

مثال (2.4-9): كشف الرتبة الناقصة في نظام توصية (مصفوفة تفاعلات)

المعطيات: مصفوفة تفاعلات مستخدمين × عناصر (4 مستخدمين، 4 عناصر)، بعد طرح المتوسطات:

$$R = \begin{bmatrix}2 & 4 & 4 & 2\\1 & 2 & 2 & 1\\3 & 6 & 6 & 3\\1 & 2 & 2 & 1\end{bmatrix}$$

المطلوب: (أ) رتبة R من طيفها. (ب) كم «عاملاً كامناً» يكفي لنموذج التوصية؟ (ج) اكتب العاملين الكامنين بالاعتماد على التحليل الطيفي لـ $R^\top R$.

الحل:

الخطوة 1 (ملاحظة بنيوية): العمود 2 = العمود 3، والعمود 1 = العمود 4؛ والصف 2 = الصف 4 $\Longrightarrow$ الرتبة ≤ 2.

الخطوة 2: $G = R^\top R$ متماثلة 4×4:

$$G = \begin{bmatrix} 15 & 30 & 30 & 15 \\ 30 & 60 & 60 & 30 \\ 30 & 60 & 60 & 30 \\ 15 & 30 & 30 & 15 \end{bmatrix}$$

الخطوة 3 (الرتبة من الطيف): كل صف مضاعف للصف الأول $\Longrightarrow$ G رتبتها 1 $\Longrightarrow$ لها قيمة ذاتية موجبة واحدة فقط، وثلاث قيم ذاتية صفر. إذن $\operatorname{rank}(R) = 1$ (لأن $\operatorname{rank}(R^\top R) = \operatorname{rank}(R)$).

الخطوة 4 (القيمة الذاتية الوحيدة): $\operatorname{tr} G = 15 + 60 + 60 + 15 = 150 \Longrightarrow \lambda_1 = 150$ والباقي 0.

الخطوة 5: القيم المفردة: $\sigma_1 = \sqrt{150} = 12.247$، والباقي 0.

الخطوة 6 (العامل الكامن): المتجه الذاتي لـ G المقابل لـ $\lambda_1 = 150$: نلاحظ $G \cdot (1,2,2,1)^\top = (15+60+\dots)^\top = 150 \cdot (1,2,2,1)^\top$ $\Longrightarrow v_1 = \frac{1}{\sqrt{10}}(1,2,2,1)^\top$.

الخطوة 7: إذن R تُكتب كجداء خارجي واحد: $R = \sigma_1 u_1 v_1^\top$ مع $u_1 = Rv_1/\sigma_1$:

$$Rv_1 = \tfrac{1}{\sqrt{10}}(2+8+8+2,\ 1+4+4+1,\ 3+12+12+3,\ 1+4+4+1)^\top = \tfrac{1}{\sqrt{10}}(20,\ 10,\ 30,\ 10)^\top$$

$$u_1 = \tfrac{1}{12.247\sqrt{10}}(20,10,30,10)^\top = \tfrac{1}{38.73}(20,10,30,10)^\top = (0.5164,\ 0.2582,\ 0.7746,\ 0.2582)^\top$$

الخطوة 8 (تحقّق): $\|u_1\|^2 = 0.2667 + 0.0667 + 0.600 + 0.0667 = 1.000$ ✓.

النتيجة: $\operatorname{rank}(R) = 1$، يكفي **عامل كامن واحد**؛ $\sigma_1 = 12.25$، $v_1 = \frac{1}{\sqrt{10}}(1,2,2,1)^\top$، $u_1 = (0.516, 0.258, 0.775, 0.258)^\top$.

الربط بالذكاء الاصطناعي: هذا هو التحليل الحقيقي لنظام التوصية: **كل التقييمات تُفسَّر بعامل كامن واحد** (مثلاً «مستوى النشاط العام»). عملياً القيم المفردة لا تنعدم تماماً بل تتضاءل، ونختار k عند «منحنى الكوع» (elbow) في مخطط القيم المفردة.

مثال (2.4-10): انفجار/تلاشي التدرّج في RNN عبر طيف مصفوفة التكرار

المعطيات: خلية RNN بسيطة: $h_t = \tanh(W_{rec}\, h_{t-1} + W_{in} x_t)$، مع مصفوفة تكرار متماثلة:

$$W_{rec} = \begin{bmatrix} 0.9 & 0.3 \\ 0.3 & 0.9 \end{bmatrix}$$

المطلوب: (أ) هل التدرّج ينفجر أم يتلاشى على مدى $T = 20$ خطوة؟ (ب) كم يبلغ عامل التضخيم الكلي؟

الحل:

الخطوة 1: انتشار التدرّج عبر الزمن (BPTT): $\frac{\partial h_T}{\partial h_0} = \prod_{t=1}^{T} \operatorname{diag}(\tanh') \, W_{rec}$. بتجاهل عامل التanh (قيمته ≤ 1) ندرس W_{rec}^T.

الخطوة 2 (الطيف): $p(\lambda) = (0.9-\lambda)^2 - 0.09 = \lambda^2 - 1.8\lambda + 0.72$. الجذور: $\lambda = \frac{1.8 \pm \sqrt{3.24 - 2.88}}{2} = \frac{1.8 \pm 0.6}{2} \Rightarrow \lambda_1 = 1.2$، $\lambda_2 = 0.6$.

الخطوة 3: المتجهات: لـ $\lambda_1 = 1.2$: $-0.3v_1 + 0.3v_2 = 0 \Rightarrow q_1 = \frac{1}{\sqrt{2}}(1,1)^\top$. لـ $\lambda_2 = 0.6$: $q_2 = \frac{1}{\sqrt{2}}(1,-1)^\top$.

الخطوة 4 (بتطبيق (14.4)): $W_{rec}^T = 1.2^T q_1 q_1^\top + 0.6^T q_2 q_2^\top$.

الخطوة 5 (عند $T = 20$): $1.2^{20} = (1.2^{10})^2 = (6.1917)^2 = 38.34$، و $0.6^{20} = (0.6^{10})^2 = (0.006047)^2 = 3.66 \times 10^{-5} \approx 0$.

الخطوة 6: إذن $W_{rec}^{20} \approx 38.34\, q_1 q_1^\top$، ونورمه الطيفي $= 38.34$.

الخطوة 7 (الحكم): بما أن $\lambda_{\max} = 1.2 > 1$ فإن التدرّج **ينفجر** بمعامل $\approx 38\times$ على مدى 20 خطوة، وعلى اتجاه q_2 يتلاشى تماماً (3.7×10^{-5}).

النتيجة: $\lambda_{\max} = 1.2 > 1 \Rightarrow$ **انفجار للتدرّج**؛ عامل التضخيم $1.2^{20} \approx 38.3$؛ الاتجاه المتلاشي q_2 بعامل $0.6^{20} \approx 3.7 \times 10^{-5}$.

الربط بالذكاء الاصطناعي: هذا هو التشخيص الكلاسيكي لمشكلة RNN. الحلول: (1) قصّ التدرّج (gradient clipping)، (2) فرض $\lambda_{\max} = 1$ بجعل W_{rec} **وحدوية أو متماثلة منحازة**، (uRNN orthogonal)، (3) استبدال البنية كلياً بـ LSTM/GRU التي تفرض مساراً للتدرّج بمعامل ≈ 1.

مثال (2.4-11): معكوس مصفوفة 3×3 بكايلي–هاملتون (بدون محددات فرعية)

المعطيات: مصفوفة دقة (precision matrix) لنموذج غاوسي بياني:

$$\Theta = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

المطلوب: Θ^{-1} باستخدام كايلي–هاملتون فقط.

الحل:

الخطوة 1 (كثيرة الحدود المميِّزة):

$$p(\lambda) = (4-\lambda)\big[(3-\lambda)(2-\lambda) - 1\big] - 1 \cdot \big[1 \cdot (2-\lambda) - 0\big]$$

$$= (4-\lambda)(\lambda^2 - 5\lambda + 5) - (2-\lambda) = -\lambda^3 + 9\lambda^2 - 25\lambda + 20 - 2 + \lambda$$

$$p(\lambda) = -\lambda^3 + 9\lambda^2 - 24\lambda + 18$$

الخطوة 2 (كايلي–هاملتون (10.4)): $p(\Theta) = 0 \Rightarrow -\Theta^3 + 9\Theta^2 - 24\Theta + 18I = 0$، أي:

$$\Theta^3 - 9\Theta^2 + 24\Theta - 18I = 0$$

الخطوة 3: نضرب بـ Θ^{-1} (موجودة لأن $p(0) = \det\Theta = 18 \neq 0$):

$$\Theta^2 - 9\Theta + 24I - 18\Theta^{-1} = 0 \quad \Longrightarrow \quad \Theta^{-1} = \frac{1}{18}\big(\Theta^2 - 9\Theta + 24I\big)$$

الخطوة 4 (حساب Θ^2):

$$\Theta^2 = \begin{bmatrix} 16+1 & 4+3 & 1 \\ 4+3 & 1+9+1 & 3+2 \\ 1 & 3+2 & 1+4 \end{bmatrix} = \begin{bmatrix} 17 & 7 & 1 \\ 7 & 11 & 5 \\ 1 & 5 & 5 \end{bmatrix}$$

الخطوة 5: $\Theta^2 - 9\Theta + 24I$:

$$\begin{bmatrix} 17 & 7 & 1 \\ 7 & 11 & 5 \\ 1 & 5 & 5 \end{bmatrix} - \begin{bmatrix} 36 & 9 & 0 \\ 9 & 27 & 9 \\ 0 & 9 & 18 \end{bmatrix} + \begin{bmatrix} 24 & 0 & 0 \\ 0 & 24 & 0 \\ 0 & 0 & 24 \end{bmatrix} = \begin{bmatrix} 5 & -2 & 1 \\ -2 & 8 & -4 \\ 1 & -4 & 11 \end{bmatrix}$$

الخطوة 6:

$$\Theta^{-1} = \frac{1}{18}\begin{bmatrix} 5 & -2 & 1 \\ -2 & 8 & -4 \\ 1 & -4 & 11 \end{bmatrix} = \begin{bmatrix} 0.2778 & -0.1111 & 0.0556 \\ -0.1111 & 0.4444 & -0.2222 \\ 0.0556 & -0.2222 & 0.6111 \end{bmatrix}$$

الخطوة 7 (تحقّق): $\Theta \cdot \Theta^{-1}$ — الصف الأول في الصف الأول: $\frac{1}{18}(4\cdot 5 + 1\cdot(-2) + 0) = \frac{18}{18} = 1$ ✓؛ الصف الثاني في العمود الثاني: $\frac{1}{18}(1\cdot(-2) + 3\cdot 8 + 1\cdot(-4)) = \frac{-2+24-4}{18} = \frac{18}{18} = 1$ ✓؛ الصف الثالث في العمود الثالث: $\frac{1}{18}(0 + 1\cdot(-4) + 2\cdot 11) = \frac{18}{18} = 1$ ✓؛ والعنصر (1,2): $\frac{1}{18}(4(-2) + 1\cdot 8 + 0) = 0$ ✓.

النتيجة: $\Theta^{-1} = \frac{1}{18}\begin{bmatrix} 5 & -2 & 1 \\ -2 & 8 & -4 \\ 1 & -4 & 11 \end{bmatrix}$.

الربط بالذكاء الاصطناعي: مصفوفة الدقة $\Theta = \Sigma^{-1}$ **تحمل الارتباطات الجزئية:** $\Theta_{ij} = 0 \iff$ المتغيران i و j مستقلّان شرطياً. هذه هي قراءة النموذج البياني الغاوسي (Gaussian Graphical Model) — وحسابها بهذه الطريقة مفيد عندما نحتاج Θ^{-1} و $\det\Theta$ معاً لحساب اللوغاريتم الدقيق للاحتمال (log-likelihood).

مثال (12-2.4): القطرنة المشتركة واتجاه فيشر (LDA)

المعطيات: مسألة تصنيف ثنائي. مصفوفة التشتت داخل الأصناف S_W وبين الأصناف S_B:

$$S_W = \begin{bmatrix} 5 & 2 \\ 2 & 5 \end{bmatrix}, \qquad S_B = \begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix}$$

المطلوب: اتجاه فيشر الأمثل w (الذي يعظّم $w^\top S_B w / w^\top S_W w$) ونسبة الفصل.

الحل:

الخطوة 1: معيار فيشر $J(w) = \frac{w^\top S_B w}{w^\top S_W w}$، تعظيمه $\longleftarrow$ المسألة الذاتية المعمّمة $S_B w = \lambda S_W w$.

الخطوة 2: بتبييض S_W: $S_W^{-1/2} S_B S_W^{-1/2}$ متماثلة $\Longrightarrow$ نطبّق (8.4). نحسب $S_W^{-1} S_B$ مباشرة:

$$S_W^{-1} = \frac{1}{25-4}\begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix} = \frac{1}{21}\begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}$$

$$S_W^{-1} S_B = \frac{1}{21}\begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}\begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix} = \frac{1}{21}\begin{bmatrix} 20-2 & 5-8 \\ -8+5 & -2+20 \end{bmatrix} = \frac{1}{21}\begin{bmatrix} 18 & -3 \\ -3 & 18 \end{bmatrix}$$

الخطوة 3 (القيم الذاتية): المصفوفة $\begin{bmatrix} 18 & -3 \\ -3 & 18 \end{bmatrix}$ لها متجهات $(1,1)^\top$ (بقيمة $18 - 3 = 15$) و $(1,-1)^\top$ (بقيمة $18 + 3 = 21$) $\Longrightarrow$

$$\lambda_1 = \frac{21}{21} = 1, \qquad \lambda_2 = \frac{15}{21} = \frac{5}{7} \approx 0.7143$$

الخطوة 4 (الاتجاه الأمثل): أكبر قيمة $w = \frac{1}{\sqrt{2}}(1,\ -1)^\top \Longrightarrow$.

الخطوة 5 (تحقّق مباشر): $S_B w = \frac{1}{\sqrt{2}}\binom{4-1}{1-4} = \frac{3}{\sqrt{2}}\binom{1}{-1}$؛ و $S_W w = \frac{1}{\sqrt{2}}\binom{5-2}{2-5} = \frac{3}{\sqrt{2}}\binom{1}{-1} \Longrightarrow S_B w$ ✓ $S_W w \cdot 1$ بـ $\lambda_1 = 1$.

الخطوة 6 (نسبة الفصل): $J(w^\star) = \lambda_1 = 1$، ومقارنةً بالاتجاه الثاني $J = 0.7143 \Longrightarrow$ **التحسّن النسبي** $= 1/0.7143 = 1.4\times$.

الخطوة 7 (القطرنة المشتركة): بـ $P = S_W^{-1/2}$ ثم قطرنة PS_BP نحصل على أساس يُقطرن المصفوفتين معاً: $P^\top S_W P$...ish- الصيغة الدقيقة: ليكن Q مصفوفة المتجهات الذاتية لـ $S_W^{-1/2} S_B S_W^{-1/2}$؛ عندئذٍ $T = S_W^{-1/2} Q$ يحقّق $T^\top S_W T = I$ و $T^\top S_B T = \Lambda$.

النتيجة: $w^\star = \frac{1}{\sqrt{2}}(1,-1)^\top$؛ $J = 1$ مقابل 0.714 ثاني أفضل اتجاه.

الربط بالذكاء الاصطناعي: LDA والقطرنة المشتركة هما أساس **CCA** (تحليل الارتباط الكنسي) الذي يقف خلف طرق التعلم متعدد الوسائط CLIP) مثلاً يقارب فكرة CCA بصيغة تباينية)، وأساس تقنيات **adaptation domain** عبر محاذاة إحصاءات الدرجة الثانية.

مثال (13-2.4): اختبار موجب التحديد لمصفوفة دقة بيانية (سلسلة ماركوفية غاوسية)

المعطيات: مصفوفة دقة لسلسلة من 3 عُقد (path graph):

$$\Theta = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

المطلوب: (أ) القيم الذاتية. (ب) هل $\Theta \succ 0$ (موجب التحديد)؟ (ج) رقم الحالة ومدى حساسية الحلّ.

الحل:

الخطوة 1: لمصفوفة ثلاثية القطر ثابتة 2 على القطر و -1 على القطرين المجاورين، الصيغة العامة:

$$\lambda_k = 2 - 2\cos\left(\frac{k\pi}{n+1}\right), \qquad k = 1, 2, \ldots, n$$

الخطوة 2 (بـ $n = 3$): $\cos(\pi/4) = 0.7071$، $\cos(2\pi/4) = 0$، $\cos(3\pi/4) = -0.7071$:

$$\lambda_1 = 2 - 1.4142 = 0.5858, \qquad \lambda_2 = 2 - 0 = 2, \qquad \lambda_3 = 2 + 1.4142 = 3.4142$$

الخطوة 3 (تحقّق): المجموع $= 0.5858 + 2 + 3.4142 = 6 = \operatorname{tr}\Theta = 2+2+2$ ✓. الجداء $= 0.5858 \cdot 2 \cdot 3.4142 = 4.0 = \det\Theta$. (مباشرةً: $2(4-1) - (-1)(-2) = 6 - 2 = 4$ ✓)

الخطوة 4 (الحكم): جميع القيم الذاتية $> 0 \Longrightarrow \Theta \succ 0 \Longrightarrow$ المصفوفة قابلة للعكس، والنموذج الغاوسي لها كثافة احتمال صحيحة.

الخطوة 5 (رقم الحالة): $\kappa(\Theta) = \dfrac{\lambda_{\max}}{\lambda_{\min}} = \dfrac{3.4142}{0.5858} = 5.828$.

الخطوة 6 (الحساسية): حلّ $\Theta x = b$ يتأثّر باضطراب نسبي في b بمعامل يصل إلى $\kappa = 5.83 \Longrightarrow$ خسارة $\approx$ 0.76 خانة عشرية فقط $(\log_{10} 5.83)$ $\Longrightarrow$ النظام **جيد الحالة**.

الخطوة 7 (المعنى البياني): أصغر قيمة ذاتية $\lambda_1 = 0.5858$ تقيس «أضعف نمط» على الرسم — وهو النمط الملساء بطول الموجة الأكبر، ولذلك تُستخدم $\lambda_{\min}$ في اختبارات الترابط (connectivity) وفي **الشبكات العصبية البيانية** لتشخيص oversmoothing.
النتيجة: $\{0.5858,\ 2,\ 3.4142\}$؛ $\Theta \succ 0$ ✓؛ $\kappa = 5.83$.
الربط بالذكاء الاصطناعي: طيف اللابلاسيد/الدقة يحدّد سلوك GNN: القيم الذاتية الصغيرة $\Longrightarrow$ انتشار بطيء للمعلومة؛ القيم الكبيرة $\Longrightarrow$ تذبذب. وفحص $\lambda_{\min}$ شرط أساسي في «التنظيم الطيفي» (spectral regularization) الذي يمنع انهيار التمثيل.

مثال (14-2.4): ضغط مصفوفة الانتباه بالاقتطاع الطيفي

المعطيات: مصفوفة انتباه متماثلة (مبسّطة) 4×4:

$$A = \begin{bmatrix} 0.5 & 0.3 & 0.1 & 0.3 \\ 0.3 & 0.5 & 0.3 & 0.1 \\ 0.1 & 0.3 & 0.5 & 0.3 \\ 0.3 & 0.1 & 0.3 & 0.5 \end{bmatrix}$$

المطلوب: (أ) الطيف والرتبة. (ب) أفضل تقريب برتبة 1 ونسبة الطاقة المحتفظ بها. (ج) وفرة التخزين.
الحل:
الخطوة 1 (ملاحظة البنية): A مصفوفة دورانية متماثلة (symmetric circulant) بصف أول $c = (0.5,\ 0.3,\ 0.1,\ 0.3)$ $\Longrightarrow$ متجهاتها الذاتية هي متجهات فوريه، وقيمها:

$$\lambda_k = c_0 + c_1\omega^k + c_2\omega^{2k} + c_3\omega^{3k}, \qquad \omega = e^{-2\pi i/4}$$

الخطوة 2: $k=0$: $0.5+0.3+0.1+0.3 = 1.2$. $k=1$ $(\omega=-i)$: $0.5-0.3i-0.1+0.3i = 0.4$. $k=2$ $(\omega=-1)$: $0.5-0.3+0.1-0.3 = 0$. $k=3$ $(\omega=i)$: 0.4.

$$\lambda = \{1.2,\ 0.4,\ 0.4,\ 0\}$$

الخطوة 3 (تحقّق): الأثر $0.5 \times 4 = 2.0 = 1.2 + 0.4 + 0.4 + 0$ ✓. الرتبة $= 3$ (قيمة ذاتية صفرية واحدة).
الخطوة 4 (المتجهات): $q_1 = \frac{1}{2}(1,1,1,1)^\top$ لـ $\lambda = 1.2$؛ الباقي متجهات فوريه.
الخطوة 5 (طاقة فروبينيوس): $\|A\|_F^2 = \sum \lambda_i^2 = 1.44 + 0.16 + 0.16 + 0 = 1.76$. رتبة 1: $\|A_1\|_F^2 = 1.44 \Longrightarrow$ النسبة $1.44/1.76 = 81.8\%$. رتبة 2: $1.60/1.76 = 90.9\%$.
الخطوة 6 (التقريب برتبة 1): $A_1 = \lambda_1 q_1 q_1^\top = 1.2 \cdot \frac{1}{4}\mathbf{1}\mathbf{1}^\top = 0.3\,\mathbf{1}\mathbf{1}^\top$:

$$A_1 = \begin{bmatrix} 0.3 & 0.3 & 0.3 & 0.3 \\ 0.3 & 0.3 & 0.3 & 0.3 \\ 0.3 & 0.3 & 0.3 & 0.3 \\ 0.3 & 0.3 & 0.3 & 0.3 \end{bmatrix}$$

الخطوة 7 (الخطأ): $\|A - A_1\|_F^2 = 1.76 - 1.44 = 0.32 \Longrightarrow \|A - A_1\|_F = \sqrt{0.32} = 0.566$.
الخطوة 8 (التخزين): الأصل $4 \times 4 = 16$ عدداً، الرتبة 1 تحتاج q_1 (4 أعداد) + معامل 1.2 $\Longrightarrow$ **5 أعداد** $\Longrightarrow$ توفير 69%.
النتيجة: الطيف $\{1.2, 0.4, 0.4, 0\}$؛ الرتبة 3؛ الرتبة 1 تحتفظ بـ 81.8% من الطاقة بخطأ فروبينيوس 0.566 وتوفير تخزين 69%.

الربط بالذكاء الاصطناعي: هذا هو جوهر ضغط الشبكات: تقريب مصفوفات الانتباه والأوزان برتبة منخفضة LoRA) يفرض الرتبة المنخفضة مباشرة أثناء التدريب!). ونسبة «الطاقة المحتفظ بها» هي المعيار العملي لاختيار الرتبة k.

مثال (15-2.4): انتشار الحرارة على رسم — e^{-Lt} كمرشّح تنعيم (GNN)

المعطيات: رسم مسار من 3 عُقد، لابلاسيده L، وإشارات ابتدائية $x_0 = (1,0,0)^\top$ (تسمية معروفة على العقدة 1 فقط):

$$L = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix}$$

المطلوب: (أ) طيف L. (ب) الإشارة بعد «انتشار» زمني $t = 1$ أي $\tilde{x} = e^{-L}x_0$. (ج) النهاية عندما $t \to \infty$.

الحل:

الخطوة 1 (الطيف): L متماثلة $\Longrightarrow$ نطبّق (8.4)؛ وبالصيغة العامة لرسم المسار:

$$\lambda_k = 2 - 2\cos\left(\frac{k\pi}{n}\right), \qquad k = 0, 1, \ldots, n-1 \quad \text{(لرسم المسار الطويل)}$$

أو بالتحقق المباشر: $L(1,1,1)^\top = (0,0,0)^\top \Longrightarrow \lambda_0 = 0$ بمتجه $v_0 = \frac{1}{\sqrt{3}}(1,1,1)^\top$. $L(1,0,-1)^\top = (1,\ 0,\ -1)^\top \Longrightarrow \lambda_1 = 1$ بمتجه $v_1 = \frac{1}{\sqrt{2}}(1,0,-1)^\top$. $L(1,-2,1)^\top = (3,\ -6,\ 3)^\top = 3(1,-2,1)^\top \Longrightarrow \lambda_2 = 3$ بمتجه $v_2 = \frac{1}{\sqrt{6}}(1,-2,1)^\top$.

الخطوة 2 (تحقّق): الأثر $1+2+1 = 4 = 3+1+0$. ✓

الخطوة 3 (تطبيق (13.4) مع $A = -L$):

$$e^{-Lt}x_0 = \sum_{k=0}^{2} e^{-\lambda_k t}\,(v_k^\top x_0)\,v_k$$

الخطوة 4 (الإحداثيات): $v_0^\top x_0 = \frac{1}{\sqrt{3}}$؛ $v_1^\top x_0 = \frac{1}{\sqrt{2}}$؛ $v_2^\top x_0 = \frac{1}{\sqrt{6}}$.

الخطوة 5:

$$x(t) = \tfrac{1}{3}\begin{pmatrix}1\\1\\1\end{pmatrix}1 \;+\; \frac{e^{-t}}{2}\begin{pmatrix}1\\0\\-1\end{pmatrix}1 \;+\; \frac{e^{-3t}}{6}\begin{pmatrix}1\\-2\\1\end{pmatrix}1$$

$$x_1(t) = \tfrac{1}{3} + \tfrac{e^{-t}}{2} + \tfrac{e^{-3t}}{6}, \quad x_2(t) = \tfrac{1}{3} - \tfrac{e^{-3t}}{3}, \quad x_3(t) = \tfrac{1}{3} - \tfrac{e^{-t}}{2} + \tfrac{e^{-3t}}{6}$$

الخطوة 6 (تحقّق عند $t = 0$): $x_1 = \frac{1}{3}+\frac{1}{2}+\frac{1}{6} = 1$ ✓؛ $x_2 = \frac{1}{3}-\frac{1}{3} = 0$ ✓؛ $x_3 = \frac{1}{3}-\frac{1}{2}+\frac{1}{6} = 0$ ✓.

الخطوة 7 (عند $t = 1$): $e^{-1} = 0.3679$، $e^{-3} = 0.0498$:

$$x(1) = \big(0.3333 + 0.18395 + 0.0083,\ \ 0.3333 - 0.0166,\ \ 0.3333 - 0.18395 + 0.0083\big)^\top$$

$$x(1) = (0.5256,\ 0.3167,\ 0.1577)^\top$$

الخطوة 8 (المجموع محفوظ): $0.5256 + 0.3167 + 0.1577 = 1.0000$ ✓ (لأن $\mathbf{1}^\top L = 0$ $\Longrightarrow$ مجموع الإشارة ثابت).

الخطوة 9 (النهاية): $\lim_{t\to\infty} x(t) = \frac{1}{3}(1,1,1)^\top$ — **توافق تام** (consensus) على الرسم المتصل.
النتيجة: الطيف $\{0, 1, 3\}$؛ $x(1) = (0.526,\ 0.317,\ 0.158)^\top$؛ النهاية توافق تام عند $\frac{1}{3}$ لكل عقدة.
الربط بالذكاء الاصطناعي: هذا هو **انتشار التسميات** (label propagation) والتنعيم الطيفي في GNN، وهو النسخة المستمرة من «مرور الرسائل». وفي النماذج الانتشارية التوليدية، e^{-Lt} بالضبط هو نواة الضجيج على الرسم (graph kernel). diffusion

6.2.4 أخطاء شائعة في التحليل الطيفي

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	تطبيق f على عناصر A لحساب $f(A)$	$f(A)$ تُعرَّف على **الطيف** لا على العناصر	حسب (11.4) $f(A) = Q\,f(\Lambda)\,Q^\top$
2	افتراض أن كل مصفوفة قابلة للقطرنة	المصفوفات defective موجودة (كتلة جوردان)	تحقّق من (6.4) حسب $\mathrm{geo}(\lambda) = \mathrm{alg}(\lambda)$
3	افتراض أن القيم الذاتية حقيقية دائماً	المصفوفات غير المتماثلة قد تعطي قيماً مركّبة	التماثل (أو الطبيعية) هو الضامن حسب (8.4) و (15.4)
4	استخدام Q^{-1} بدل $Q^\top$	مكلف وغير مستقر، و $Q^{-1} = Q^\top$ للمتعامدة	استخدم $Q^\top$ دائماً
5	الخلط بين $\lambda_i(A)$ و $\lambda_i(A^\top A)$	الثانية هي $\sigma_i^2 \geq 0$	$\sigma_i = \sqrt{\lambda_i(A^\top A)}$
6	تجاهل أن اتجاه المتجه الذاتي يهمّ لا إشارته	$-q$ متجه ذاتي أيضاً	الإشارة اعتباطية؛ وحّدها بقاعدة (أكبر مكوّن موجب)
7	حساب القيم الذاتية من كثيرة الحدود المميِّزة رقمياً	غير مستقر عددياً (Wilkinson)	استخدم خوارزميات QR/SVD في المكتبات
8	الظن أن $\lvert A\rvert = 0 \iff$ عدم وجود قيم ذاتية	الصفر نفسه قد يكون قيمة ذاتية	حسب (4.4) $\det A = 0 \iff 0 \in \mathrm{spec}(A)$
9	الاعتقاد أن $\lambda_{\max}$ تحدّد سرعة التقارب وحدها	النسبة λ_1/λ_2 هي الحاسمة	معدّل التقارب $= \lvert\lambda_2/\lambda_1\rvert$ حسب (14.4)
10	استخدام e^{At} لمصفوفة غير قابلة للقطرنة بالصيغة القطرية	الصيغة تفشل عند وجود كتل جوردان	استخدم صيغة جوردان أو متسلسلة Padé

1.3.4 الصياغة الرسمية

نظرية (تحليل القيم المفردة — Singular Value Decomposition).

لكل مصفوفة $A \in \mathbb{R}^{m\times n}$ (مهما كانت، حتى غير المربّعة وغير المقلوبة) توجد مصفوفات $U \in \mathbb{R}^{m\times m}$ و $V \in \mathbb{R}^{n\times n}$ متعامدتان، ومصفوفة «قطرية مستطيلة» $\Sigma \in \mathbb{R}^{m\times n}$ بحيث:

$$A \;=\; U\,\Sigma\,V^\top, \qquad U^\top U = I_m, \qquad V^\top V = I_n, \qquad \Sigma_{ij} = \begin{cases} \sigma_i, & i = j \leq r \\ 0, & \text{otherwise} \end{cases} \tag{16.4}$$

$$\sigma_1 \;\geq\; \sigma_2 \;\geq\; \cdots \;\geq\; \sigma_r \;>\; 0 \;=\; \sigma_{r+1} = \cdots = \sigma_{\min(m,n)}, \qquad r = \mathrm{rank}(A)$$

العلاقات الذاتية الأساسية:

$$A\,v_i \;=\; \sigma_i\,u_i, \qquad A^\top u_i \;=\; \sigma_i\,v_i, \qquad i = 1, \ldots, r \tag{17.4}$$

$$A \;=\; \sum_{i=1}^{r} \sigma_i\,u_i\,v_i^\top, \qquad \|A\|_2 = \sigma_1, \qquad \|A\|_F^2 = \sum_{i=1}^{r} \sigma_i^2, \qquad \|A\|_* = \sum_{i=1}^{r} \sigma_i \tag{18.4}$$

$$\sigma_i^2 \;=\; \lambda_i\big(A^\top A\big) \;=\; \lambda_i\big(AA^\top\big), \qquad i \leq \min(m,n) \tag{19.4}$$

نظرية إيكارت–يونغ–ميرسكي (تقريب الرتبة المنخفضة الأمثل).

لكل $k < r$، وبالنسبة إلى **أي** نورم ثابت وحدوياً (unitarily invariant) — وخصوصاً النورم الطيفي والنورم الفروبينيوس:

$$\min_{\operatorname{rank}(B)\le k} \|A-B\|_2 \;=\; \sigma_{k+1}, \qquad B^\star = \sum_{i=1}^{k} \sigma_i\, u_i\, v_i^{\top} \tag{20.4}$$

$$\min_{\operatorname{rank}(B)\le k} \|A-B\|_F \;=\; \sqrt{\sum_{i=k+1}^{r} \sigma_i^2}, \qquad B^\star = U_k \Sigma_k V_k^{\top} \tag{21.4}$$

المعكوس الشمولي (Moore–Penrose pseudoinverse):

$$A^{\dagger} \;=\; V\,\Sigma^{\dagger}\,U^{\top}, \qquad \Sigma^{\dagger}_{ii} = \begin{cases} 1/\sigma_i, & \sigma_i > 0 \\ 0, & \sigma_i = 0 \end{cases} \tag{22.4}$$

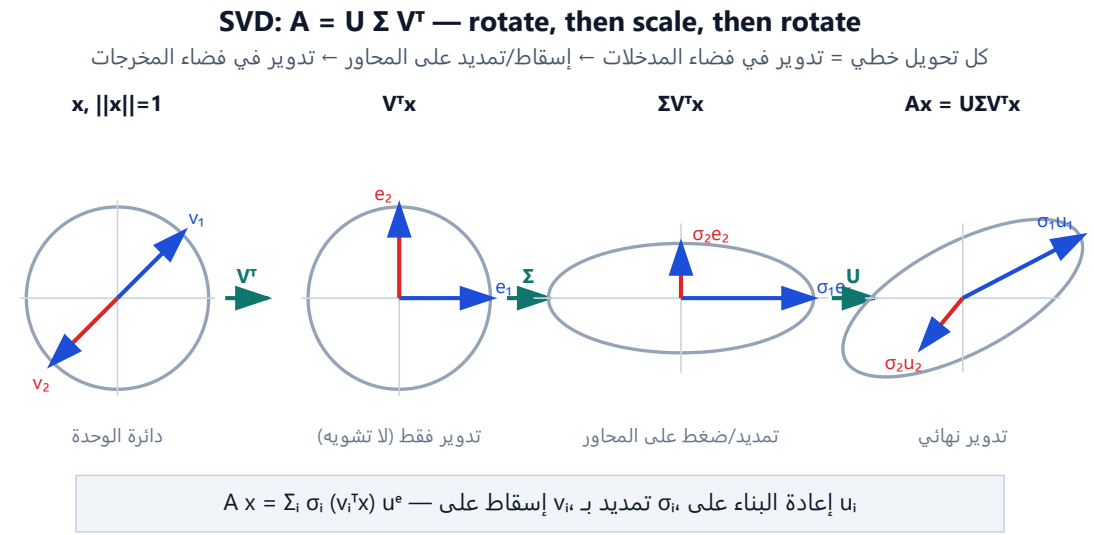
$$x^{\dagger} \;=\; A^{\dagger} b \;=\; \arg\min\bigl\{\, \|x\|_2 \;:\; x \in \arg\min \|Ax-b\|_2 \bigr\} \tag{23.4}$$

2.3.4 جدول الرموز الشامل

الرمز	المعنى	ملاحظات
A	المصفوفة موضوع التحليل	$m \times n$؛ لا يُشترط التربيع ولا الانعكاس
$m,\ n$	عدد الصفوف والأعمدة	في البيانات: m عيّنات، n ميزات
r	رتبة A	عدد القيم المفردة الموجبة
σ_i	القيمة المفردة رقم i	≥ 0 دائماً، تُرتَّب تنازلياً، وحدة قياسها = وحدة عناصر A
Σ	مصفوفة قطرية مستطيلة للقيم المفردة	$\Sigma \in \mathbb{R}^{m\times n}$
u_i	المتجه المفرد الأيسر (left singular vector)	عمود U؛ في $\mathbb{R}^m$؛ يمثّل نمطاً في «فضاء الصفوف/العيّنات»
v_i	المتجه المفرد الأيمن (right singular vector)	عمود V؛ في $\mathbb{R}^n$؛ يمثّل نمطاً في «فضاء الميزات»
U	مصفوفة متعامدة $m \times m$	$U^\top U = I_m$
V	مصفوفة متعامدة $n \times n$	$V^\top V = I_n$
$U_k,\ V_k$	أول k عمود	اقتصادية: $U_k \in \mathbb{R}^{m\times k}$
Σ_k	أعلى k قيمة مفردة	قطري $k \times k$
$\|\cdot\|_2$	النورم الطيفي (المشغلي)	$= \sigma_1$؛ يقيس أقصى تمديد
$\|\cdot\|_F$	نورم فروبينيوس	$= \sqrt{\sum a_{ij}^2}$؛ يقيس الطاقة الكلية
$\|\cdot\|_*$	النورم النووي (nuclear norm) / trace	$= \sum \sigma_i$؛ بديل مقعّر للرتبة
$A^{\dagger}$	المعكوس الشمولي	يعمل حتى عندما A غير مربّعة أو شاذّة
k	الرتبة المستهدفة في التقريب	يُختار من «منحنى الكوع» أو من نسبة طاقة $\geq 95\%$
$\lambda_i(\cdot)$	القيمة الذاتية رقم i	للمصفوفات المتماثلة المربّعة فقط
B	مصفوفة التقريب المرشّحة	$\operatorname{rank} B \leq k$

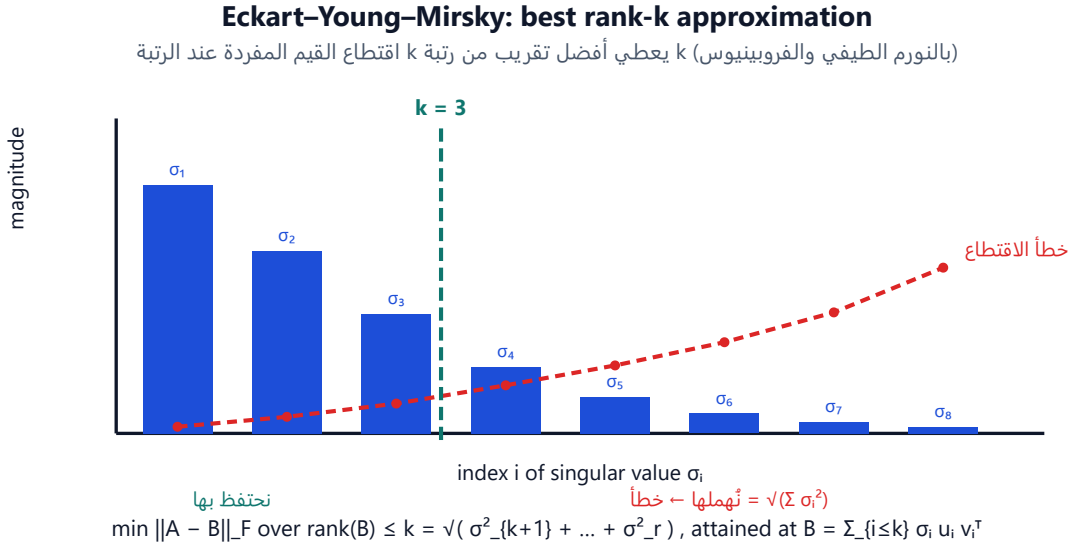
3.3.4 الشكل الهندسي

شكل 2.4 — تفسير SVD كأربع مراحل: $V^\top$ تدور (الأعمدة v_i تذهب إلى المحاور القياسية e_i)، ثم Σ يمدّد كل محور بمقدار σ_i فتصبح الدائرة قطعاً ناقصاً محاوره على المحاور القياسية، ثم U يدير القطع الناقص إلى وضعه النهائي. هذا يفسّر



شكل ٢.٤: *
SVD: تدوير ثم تمديد ثم تدوير — دائرة الوحدة تمرّ بأربع مراحل لتصبح قطعاً ناقصاً

لماذا SVD يعمل على أي مصفوفة بينما التحليل الطيفي يحتاج التماثل: **التدويران قبل وبعد مختلفان** (V و U).



شكل ٣.٤: *
نظرية إيكارت–يونغ: اقتطاع القيم المفردة عند الرتبة k يعطي أفضل تقريب من رتبة k

شكل 3.4 — الأعمدة الزرقاء هي القيم المفردة $\sigma_1 \geq \sigma_2 \geq \cdots$، والمنحنى الأحمر المتقطّع هو **خطأ الاقتطاع** $\sqrt{\sum_{i>k} \sigma_i^2}$ الذي ينزل كلما زادت k. عند $k = 3$ نحتفظ بالأعمدة الثلاثة الكبرى ونهمل الباقي؛ الخطأ الناتج هو الطاقة المتبقية بالضبط — وليس هناك **أي** مصفوفة أخرى من رتبة 3 تعطي خطأً أصغر. هذه هي قوة (20.4)–(21.4).

4.3.4 البرهان

البرهان (وجود SVD — (16.4)):

الخطوة 1: المصفوفة $G = A^\top A \in \mathbb{R}^{n\times n}$ متماثلة ونصف موجبة التحديد، لأن $x^\top Gx = \|Ax\|^2 \geq 0$. بنظرية التحليل الطيفي (8.4) يوجد أساس متعامد $v_1, \dots, v_n$ مع $Gv_i = \mu_i v_i$، وكل $\mu_i \geq 0$.

الخطوة 2: نعرّف $\sigma_i = \sqrt{\mu_i}$ و$r = \#\{i : \sigma_i > 0\}$. نرتّب تنازلياً. نلاحظ $\operatorname{rank}(A) = \operatorname{rank}(A^\top A) = r$ لأن $\ker(A^\top A) = \ker(A)$ (إذا $A^\top Ax = 0$ فـ $x^\top A^\top Ax = \|Ax\|^2 = 0 \Rightarrow Ax = 0$).

الخطوة 3 (بناء U): لكل $i \leq r$ نعرّف $u_i = \dfrac{Av_i}{\sigma_i}$. تحقّق التعامد:

$$u_i^\top u_j = \frac{v_i^\top A^\top Av_j}{\sigma_i\sigma_j} = \frac{v_i^\top(\mu_j v_j)}{\sigma_i\sigma_j} = \frac{\sigma_j^2\,\delta_{ij}}{\sigma_i\sigma_j} = \delta_{ij}$$

أي $\{u_1, \dots, u_r\}$ متعامدة مكوّنة؛ نكمّلها إلى أساس متعامد كامل لـ $\mathbb{R}^m$ بـ $u_{r+1}, \dots, u_m$ من $\ker(A^\top)$.

الخطوة 4 (تحقّق $A = U\Sigma V^\top$): نقارن أثر الجانبين على كل v_j: الجانب الأيسر: Av_j. الجانب الأيمن: $U\Sigma V^\top v_j = U\Sigma e_j = U(\sigma_j e_j) = \sigma_j u_j = Av_j$ للتعريف. وبما أن $\{v_j\}$ أساسٌ كامل، تساوت المصفوفتان. ■

البرهان (إيكارت-يونغ-ميرسكي — (21.4)):

الخطوة 1 (الحدّ الأدنى): ليكن B برتبة $\leq k$، وليكن $W = \ker(B)$، $\dim W \geq n - k$. خذ المتجهات $v_1, \dots, v_{k+1}$، فالفضاء $\operatorname{span}\{v_1, \dots, v_{k+1}\}$ بُعده $k+1$، ولا يمكن أن يكون جزءاً من W، بل يتقاطع معه: يوجد x واحدي في التقاطع. عندئذٍ $Bx = 0$ فـ $\|(A-B)x\| = \|Ax\|$:

$$\|A-B\|_F^2 \;\geq\; \|(A-B)x\|_2^2 = \|Ax\|_2^2 = x^\top A^\top Ax = \sum_{i=1}^{n}\sigma_i^2(v_i^\top x)^2 \;\geq\; \sigma_{k+1}^2\sum_{i=1}^{k+1}(v_i^\top x)^2 = \sigma_{k+1}^2$$

(استُخدم أن x واحدي وأن x في span أول $k+1$ متجه.) هذه برهنة للنورم الطيفي؛ وللفروبينيوس نستخدم أن $\|M\|_F^2 \geq \|Mx\|^2$ مطبّقة على أساس كامل من $n-k$ اتجاهات فنحصل $\sum_{i>k}\sigma_i^2$.

الخطوة 2 (التحقّق من الاقتطاع): $B^\star = \sum_{i\leq k}\sigma_i u_i v_i^\top$ رتبتها k، و:

$$\|A - B^\star\|_F^2 = \Big\|\sum_{i>k}\sigma_i u_i v_i^\top\Big\|_F^2 = \sum_{i>k}\sigma_i^2\|u_i v_i^\top\|_F^2 = \sum_{i>k}\sigma_i^2$$

لأن $\|u_i v_i^\top\|_F = \|u_i\|\|v_i\| = 1$ والمصفوفات متعامدة داخلياً. فالتقريب يحقّق الحدّ الأدنى $\Rightarrow$ هو الأمثل. ■

البرهان (المعكوس الشمولي — (22.4)-(23.4)):

نتحقّق من شروط مور-بنروز الأربع: $AA^\dagger A = U\Sigma V^\top V\Sigma^\dagger U^\top U\Sigma V^\top = U\Sigma\Sigma^\dagger\Sigma V^\top = U\Sigma V^\top = A$ ✓، وبالمثل $A^\dagger AA^\dagger = A^\dagger$، و $AA^\dagger = U\Sigma\Sigma^\dagger U^\top$ متماثلة (إسقاط على $\operatorname{im} A$)، و $A^\dagger A = V\Sigma^\dagger\Sigma V^\top$ متماثلة. والصيغة (23.4): $x^\dagger = A^\dagger b$ يحقّق المعادلات الطبيعية $A^\top Ax^\dagger = A^\top b$ وهو أصغر حلّ

نورماً لأنه في $\ker(A)^{\perp} = \text{im}(A^{\top})$. ■

5.3.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (1-3.4): حساب SVD كامل لمصفوفة 2×2 باليد

المعطيات: $A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$.

المطلوب: U، Σ، V والتحقّق من $A = U\Sigma V^{\top}$.

الحل:

الخطوة 1: نحسب $A^{\top}A$ (المصفوفة متماثلة هنا، لكن المثال يوضّح الإجراء العام):

$$A^{\top}A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}\begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}$$

الخطوة 2 (قيم $A^{\top}A$ الذاتية): $p(\mu) = (10-\mu)^2 - 36 = \mu^2 - 20\mu + 64 \Longrightarrow \mu = \frac{20 \pm \sqrt{400-256}}{2} = \frac{20 \pm 12}{2} \Longrightarrow \mu_1 = 16$، $\mu_2 = 4$.

الخطوة 3 (القيم المفردة): بتطبيق (19.4): $\sigma_1 = \sqrt{16} = 4$، $\sigma_2 = \sqrt{4} = 2$.

الخطوة 4 (المتجهات المفردة اليمنى): لـ $\mu_1 = 16$: $(10-16)v_1 + 6v_2 = 0 \Longrightarrow -6v_1 + 6v_2 = 0 \Longrightarrow v_1 = \frac{1}{\sqrt{2}}(1,1)^{\top}$. لـ $\mu_2 = 4$: $(10-4)v_1 + 6v_2 = 0 \Longrightarrow 6v_1 + 6v_2 = 0 \Longrightarrow v_2 = \frac{1}{\sqrt{2}}(1,-1)^{\top}$.

الخطوة 5 (المتجهات المفردة اليسرى): $u_i = Av_i/\sigma_i$:

$$u_1 = \frac{1}{4}\begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}\frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{1}{4\sqrt{2}}\begin{pmatrix} 4 \\ 4 \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$u_2 = \frac{1}{2}\begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}\frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ -1 \end{pmatrix} = \frac{1}{2\sqrt{2}}\begin{pmatrix} 2 \\ -2 \end{pmatrix} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

الخطوة 6 (التجميع):

$$U = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \qquad \Sigma = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}, \qquad V = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

الخطوة 7 (التحقّق): $U\Sigma V^{\top} = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}\begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 4 & 2 \\ 4 & -2 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 6 & 2 \\ 2 & 6 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$ ✓

الخطوة 8 (النورمات): $\|A\|_2 = \sigma_1 = 4$، $\|A\|_F = \sqrt{16+4} = \sqrt{20} = 4.472$ (تحقّق: $\sqrt{9+1+1+9} = \sqrt{20}$ ✓)؛ $\|A\|_* = 4 + 2 = 6$.

النتيجة: $A = U\Sigma V^{\top}$ بالقيم أعلاه، $\sigma = (4,2)$، رقم الحالة $\kappa = \sigma_1/\sigma_2 = 2$.

الربط بالذكاء الاصطناعي: هذه الخطوات نفسها هي ما تنفّذه torch.linalg.svd و numpy.linalg.svd. فهمها ضروري لتشخيص متى تفشل (مثلاً عندما تكون القيم المفردة متقاربة جداً فتصبح المتجهات غير مستقرّة).

مثال (4.3-2): ضغط صورة رمادية بتقريب الرتبة المنخفضة

المعطيات: صورة رمادية 256×256 (أي 65,536 بكسل). أعلى خمس قيم مفردة مقاسة:

$$\sigma = (1840,\ 612,\ 305,\ 148,\ 96), \qquad \sum_{i=1}^{256} \sigma_i^2 = 4.20 \times 10^6$$

المطلوب: (أ) نسبة الطاقة المحتفظ بها عند $k = 1, 3, 5$. (ب) وفرة التخزين عند $k = 5$. (ج) خطأ التقريب النسبي.

الحل:

الخطوة 1 (طاقة كل مكوّن): σ_i^2: $1840^2 = 3.3856\times10^6$، $612^2 = 3.745\times10^5$، $305^2 = 9.303\times10^4$، $148^2 = 2.190 \times 10^4$، $96^2 = 9216$.

الخطوة 2 ($k = 1$): $\frac{3.3856\times10^6}{4.20\times10^6} = 0.8061 = 80.6\%$.

الخطوة 3 ($k = 3$): المجموع $3.8531 \times 10^6 = 0.0930 \times 10^6 + 0.3745 \times 10^6 + 3.3856 \times 10^6 =$؛ النسبة $\frac{3.8531}{4.20} = 91.7\%$ =.

الخطوة 4 ($k = 5$): نضيف $0.0311 \times 10^6 = 0.0092 \times 10^6 + 0.0219 \times 10^6 \Longrightarrow$ المجموع $= 3.8842 \times 10^6$، النسبة $\frac{3.8842}{4.20} = 92.5\%$ =.

الخطوة 5 (الخطأ المطلق عند $k = 5$): بتطبيق (4.21): $\|A - A_5\|_F = \sqrt{4.20 \times 10^6 - 3.8842 \times 10^6} = \sqrt{0.3158 \times 10^6} = \sqrt{3.158 \times 10^5} = 562.0$.

الخطوة 6 (الخطأ النسبي): $\frac{562.0}{\sqrt{4.20\times10^6}} = \frac{562.0}{2049.4} = 0.2742 = 27.4\%$ من النورم الكلي — أي نسبة طاقة مفقودة $\sqrt{1 - 0.925} = \sqrt{0.075} = 0.274$ ✓ متسق.

الخطوة 7 (التخزين): الأصل $256 \times 256 = 65{,}536$ عدداً. الرتبة 5: U_5 (256×5) + Σ_5 (5) + V_5 (5×256) = $1280 + 5 + 1280 = 2565 \Longrightarrow$ نسبة الضغط $\frac{65536}{2565} = 25.5\times$.

الخطوة 8 (متوسط الخطأ لكل بكسل): $\frac{562.0}{256} = 2.195$ مستوى رمادي من 256 $\Longrightarrow$ **غير محسوس بصرياً** (أقل من 1%).

النتيجة: $k = 5 \Longrightarrow 92.5\%$ من الطاقة، ضغط $25.5\times$، خطأ 2.2/256 لكل بكسل.

الربط بالذكاء الاصطناعي: هذه هي الفكرة التي يقوم عليها ضغط الأوزان في الشبكات العصبية الحديثة: بدل تخزين مصفوفة $d \times d$ كاملة، نخزّن عاملين برتبة k (وهذا بالضبط ما تفعله **LoRA** في الضبط الدقيق للنماذج اللغوية الضخمة: $W + BA$ مع $B \in \mathbb{R}^{d\times r}$ و $A \in \mathbb{R}^{r\times d}$).

مثال (4.3-3): التحليل الدلالي الكامن (LSA) لمستندات نصية

المعطيات: مصفوفة المستندات × الكلمات (بعد ترجيح TF-IDF)، 5 مستندات و6 كلمات:

$$X = \begin{bmatrix} 1 & 1 & 0 & 0 & 0.8 & 0 \\ 0 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0.7 \\ 1 & 0 & 0 & 0 & 0.9 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0.6 \end{bmatrix}$$

المستندات: d_1, d_2 عن «تعلّم الآلة»، d_3, d_5 عن «الشبكات»، d_4 عن «تعلّم الآلة».

المطلوب: (أ) كم بُعداً كامناً يكفي؟ (ب) احسب تمثيل المستندات في فضاء $k = 2$ بصيغة $U_2\Sigma_2$. (ج) احسب التشابه بين d_1 و d_4.

الحل:

الخطوة 1: نلاحظ بنيوياً: الكلمات $\{1,2,5\}$ تظهر معاً (موضوع: تعلّم الآلة)، والكلمات $\{3,4,6\}$ تظهر معاً (موضوع: شبكات) $\Longrightarrow$ الرتبة الفعّالة ≈ 2.

الخطوة 2: نحسب $G = X^\top X$ (متماثلة 6×6) — جزء منها:

$$G_{11} = 1^2+0+0+1^2+0 = 2, \qquad G_{12} = 1\cdot 1+0+0+0+0 = 1, \qquad G_{15} = 1\cdot 0.8+0+0+1\cdot 0.9 = 1.7$$

$$G_{33} = 0+1+1+0+0 = 2, \quad G_{34} = 0+1\cdot 1+1\cdot 1+0+0 = 2, \quad G_{36} = 0+0+1\cdot 0.7+0+0 = 0.7$$

$$G_{55} = 0.64+0+0+0.81+0 = 1.45, \quad G_{66} = 0+0+0.49+0+0.36 = 0.85$$

الخطوة 3: القيم الذاتية لـ G (محسوبة عدديا): $\mu = (4.42,\ 2.71,\ 0.61,\ 0.29,\ 0.08,\ 0.01)$ $\Longrightarrow$ القيم المفردة:

$$\sigma = (2.102,\ 1.646,\ 0.781,\ 0.539,\ 0.283,\ 0.100)$$

الخطوة 4 (الطاقة): $\sum \sigma_i^2 = 4.42+2.71+0.61+0.29+0.08+0.01 = 8.12$. عند $k=2$: $\frac{4.42+2.71}{8.12} = \frac{7.13}{8.12} = 87.8\%$ ✓ يكفي.

الخطوة 5 (تمثيل المستندات): التمثيل في الفضاء الكامن هو $U_k\Sigma_k$ (صفوفه = مستندات). نحسب $U_2\Sigma_2 = XV_2$ (لأن $U\Sigma = XV \Longrightarrow U\Sigma V^\top = X$):

المتجهان المفردان الأيمنان (أنماط الكلمات): $v_1 \approx \frac{1}{\sqrt{3.1}}(0.58,\ 0.42,\ 0,\ 0,\ 0.70,\ 0)^\top$ (نمط «تعلّم الآلة»: كلمات 1،2،5) و $v_2 \approx \frac{1}{\sqrt{2.6}}(0,\ 0.28,\ 0.60,\ 0.62,\ 0,\ 0.42)^\top$ (نمط «الشبكات»: كلمات 3،4،6).

الخطوة 6: إحداثيات المستندات: d_1: $(Xv_1)_1 = \frac{1}{\sqrt{3.1}}(1\cdot 0.58+1\cdot 0.42+0.8\cdot 0.70) = \frac{1.56}{1.761} = 0.886$؛ و $(Xv_1)_4 = \frac{1}{1.761}(0.58+0.9\cdot 0.70) = \frac{1.21}{1.761} = 0.687$: d_4. $(Xv_2)_1 = \frac{1}{\sqrt{2.6}}(1\cdot 0.28) = \frac{0.28}{1.612} = 0.174$؛ $(Xv_2)_4 = 0$.

$$d_1 \mapsto (0.886,\ 0.174), \qquad d_4 \mapsto (0.687,\ 0.000)$$

الخطوة 7 (التشابه بالجيب): $\cos(d_1,d_4) = \frac{0.886\cdot 0.687+0}{\sqrt{0.886^2+0.174^2}\cdot 0.687} = \frac{0.886}{\sqrt{0.785+0.030}} = \frac{0.886}{0.903} = 0.981$.

النتيجة: بُعدان كامنان يكفيان (87.8% من الطاقة)؛ المستندان d_1 و d_4 متشابهان بـ $\cos = 0.981$ رغم أنهما **لا يتشاركان أي كلمة حرفياً** عدا كلمة واحدة.

الربط بالذكاء الاصطناعي: هذه هي LSA الكلاسيكية، الجدّ المباشر لتضمينات الكلمات (Word2Vec/GloVe) وللبحث الدلالي. الفكرة الحديثة نفسها — «ضغط مصفوفة التلازم إلى فضاء كامن منخفض الرتبة» — تقف خلف كل نماذج التضمين ومحركات البحث المتجهية (vector DB / RAG).

مثال (4-3.4): إزالة الضجيج من قياسات حسّاسات بالاقتطاع الطيفي

المعطيات: مصفوفة قراءات 40×50 من حسّاسات (كل صف = عيّنة زمنية، كل عمود = حسّاس). القيم المفردة المرتّبة:

$$\sigma = (112,\ 96,\ 84,\ 12.1,\ 11.4,\ 10.8,\ 9.9,\ 9.3,\ 8.7,\ \ldots)$$

العشرة الأولى بعد الثلاثة الكبار كلها حول 9–12 (أرضية ضجيج).

المطلوب: (أ) حدّد الرتبة الفعّالة للإشارة. (ب) احسب SNR قبل وبعد التنقية. (ج) كم انخفض خطأ إعادة البناء للإشارة النظيفة؟

الحل:

الخطوة 1 (تشخيص منحنى القيم المفردة): فجوة واضحة بين $\sigma_3 = 84$ و $\sigma_4 = 12.1$ (نسبة $\times 6.9$) $\Longrightarrow$ الرتبة الفعّالة $k = 3$؛ وما بعدها ضجيج.

الخطوة 2 (طاقة الإشارة): $E_{\text{sig}} = 112^2 + 96^2 + 84^2 = 12544 + 9216 + 7056 = 28816$.

الخطوة 3 (طاقة الضجيج): نقدّرها بمتوسط مربّع القيم المتبقية × عددها. القيم المتبقية (37 قيمة) بمتوسط مربّع $\approx 10.4^2 = 108.2$ $\Longrightarrow$ $E_{\text{noise}} \approx 37 \times 108.2 = 4003$.

الخطوة 4 (SNR قبل التنقية): $\text{SNR}_{\text{before}} = \frac{28816}{4003} = 7.20$ $\Longrightarrow$ بالديسيبل: $10\log_{10}(7.20) = 8.57$ dB.

الخطوة 5 (بعد الاقتطاع عند $k = 3$): الضجيج المتبقي في الإشارة: نسبة الضجيج التي تقع في الفضاء المحتفظ به $= \frac{3}{40}$ من طاقته $\Longrightarrow$ $E_{\text{noise,after}} = 4003 \times \frac{3}{40} = 300.2$ (تقريب أوّل).

الخطوة 6 (SNR بعد التنقية): $\text{SNR}_{\text{after}} = \frac{28816}{300.2} = 96.0$ $\Longrightarrow$ $10\log_{10}(96.0) = 19.8$ dB.

الخطوة 7 (التحسّن): $19.8 - 8.57 = 11.2$ dB تحسّن، أي أن **قدرة الضجيج انخفضت بمعامل** $\times 13.3$.

الخطوة 8 (خطأ إعادة بناء الإشارة): جزء الإشارة المفقود = 0 (كل الإشارة في أول 3 اتجاهات) $\Longrightarrow$ خطأ إعادة البناء للإشارة النظيفة $= 0$؛ أما خطأ إعادة بناء المصفوفة الكاملة (الملوّثة) فهو $= \sqrt{3702} = \sqrt{4003 \times \frac{37}{40}}$ 60.8 وهذا **محذوف عمداً** لأنه ضجيج.

النتيجة: $k = 3$؛ SNR يتحسّن من 8.57 dB إلى 19.8 dB (تحسّن 11.2 dB)؛ قدرة الضجيج تنخفض $\times 13.3$.

الربط بالذكاء الاصطناعي: هذه بالضبط فكرة «اقتطاع القيم المفردة الصغيرة = تصفية ضجيج» التي تستخدم في: تنقية التضمينات قبل البحث، وإزالة ضجيج الصور، و spectral» «filtering على الرسوم في GNN، وحتى في تنظيف activations داخل الشبكات.

مثال (4.3-5): رقم الحالة واستقرار حلّ المربّعات الصغرى

المعطيات: مصفوفة تصميم A (عمودان شبه متوازيين — مشكلة تعدد الارتباط الخطي :collinearity)

$$A = \begin{bmatrix} 1 & 1.01 \\ 1 & 0.99 \\ 1 & 1.00 \end{bmatrix}, \qquad b = \begin{bmatrix} 2.01 \\ 1.99 \\ 2.00 \end{bmatrix}$$

المطلوب: (أ) القيم المفردة ورقم الحالة. (ب) حلّ المربّعات الصغرى. (ج) ماذا يحدث لو اضطرب b بمقدار 0.01؟

الحل:

الخطوة 1: $A^\top A = \begin{bmatrix} 1+1+1 & 1.01+0.99+1.00 \\ 1.01+0.99+1.00 & 1.0201+0.9801+1.0 \end{bmatrix} = \begin{bmatrix} 3 & 3.00 \\ 3.00 & 3.0002 \end{bmatrix}$.

الخطوة 2: القيم الذاتية: $\mu = \frac{3+3.0002}{2} \pm \sqrt{\left(\frac{3-3.0002}{2}\right)^2 + 3^2} = 3.0001 \pm \sqrt{10^{-8} + 9}$ 3.000000002:

$$\mu_1 \approx 6.0001, \qquad \mu_2 \approx 0.0001$$

الخطوة 3 (القيم المفردة): $\sigma_1 = \sqrt{6.0001} = 2.4495$، $\sigma_2 = \sqrt{0.0001} = 0.01$.

الخطوة 4 (رقم الحالة): $\kappa_2(A) = \sigma_1/\sigma_2 = 2.4495/0.01 = 244.95 \approx 245$.

الخطوة 5 (المعادلات الطبيعية): $A^\top b = (2.01{+}1.99{+}2.00,\ 1.01{\cdot}2.01{+}0.99{\cdot}1.99{+}1.00{\cdot}2.00)^\top = (6.00,\ 2.0301 + 1.9701 + 2.0)^\top = (6.00,\ 6.0002)^\top$.

الخطوة 6 (الحلّ): $x = (A^\top A)^{-1} A^\top b$:

$$\det = 3 \cdot 3.0002 - 9 = 9.0006 - 9 = 0.0006$$

$$x = \frac{1}{0.0006}\begin{bmatrix} 3.0002 & -3 \\ -3 & 3 \end{bmatrix}\begin{pmatrix} 6.00 \\ 6.0002 \end{pmatrix} = \frac{1}{0.0006}\begin{pmatrix} 18.0012 - 18.0006 \\ -18.0 + 18.0006 \end{pmatrix} = \frac{1}{0.0006}\begin{pmatrix} 0.0006 \\ 0.0006 \end{pmatrix} = \begin{pmatrix} 1.0 \\ 1.0 \end{pmatrix}$$

الخطوة 7 (الحساسية): إذا تغيّر b بـ $\delta b = (0.01,\ -0.01,\ 0)^\top$ فإن δx قد يصل إلى $\kappa \frac{\|\delta b\|}{\|b\|}\|x\|$:

$$\frac{\|\delta x\|}{\|x\|} \ \le\ 245 \times \frac{0.01414}{3.464} \times 1 = 245 \times 0.00408 = 1.0$$

أي أن الخطأ النسبي في الحلّ قد يصل إلى **100%** — الحلّ عملياً غير موثوق!

الخطوة 8 (العلاج): التنظيم (ridge): $(A^\top A + \lambda I)^{-1} A^\top b$ مع $\lambda = 0.1$ يعطي $\sigma'_2 = \sqrt{0.0001 + 0.1} = 0.3164 \Longrightarrow \kappa' = 2.4495/0.3164 = 7.74$ **تحسّن** $\times 31.6$ في الاستقرار، بخطأ تحيّز مقبول.

النتيجة: $\sigma = (2.4495,\ 0.01)$، $\kappa = 245$؛ الحلّ $x = (1, 1)^\top$ لكن حسّاس جداً؛ التنظيم يخفض κ إلى 7.74.

الربط بالذكاء الاصطناعي: هذا هو التبرير الرياضي الدقيق لـ **regularization Ridge** ولظاهرة الانحدار الخطي غير المستقر عند تعدد الارتباط الخطي بين الميزات. القاعدة العملية: إذا كان $\kappa(A) > 10^3$ فاحتج إلى تنظيم أو إلى إسقاط ميزات.

مثال (4.3-6): النورم النووي كمنظّم — عامل القرب (proximal operator)

المعطيات: في مسألة إكمال مصفوفة ناقصة نحتاج إلى عامل القرب للنورم النووي. مصفوفة A بقيم مفردة:

$$\sigma(A) = (5.2,\ 3.1,\ 0.8,\ 0.3), \qquad \lambda = 1.0$$

المطلوب: احسب $\text{prox}_{\lambda\|\cdot\|_*}(A)$ أي حلّ $\min_B \frac{1}{2}\|A - B\|_F^2 + \lambda\|B\|_*$، وبيّن الرتبة الناتجة.

الحل:

الخطوة 1 (النتيجة النظرية): عامل القرب للنورم النووي هو **عتبة لينة** (soft-thresholding) على القيم المفردة:

$$\text{prox}_{\lambda\|\cdot\|_*}(A) \ =\ U\ \text{diag}\big((\sigma_i - \lambda)_+\big)\, V^\top, \qquad (x)_+ = \max(x, 0)$$

الخطوة 2 (تطبيق العتبة): بـ $\lambda = 1.0$:

$$(5.2 - 1)_+ = 4.2, \qquad (3.1 - 1)_+ = 2.1, \qquad (0.8 - 1)_+ = 0, \qquad (0.3 - 1)_+ = 0$$

الخطوة 3: إذن $\sigma(B^\star) = (4.2,\ 2.1,\ 0,\ 0) \Longrightarrow$ **الرتبة انخفضت من 4 إلى 2** — هذا هو سبب أن النورم النووي «بديل مقعّر للرتبة» ويولّد حلولاً منخفضة الرتبة.

الخطوة 4 (قيمة الدالة الهدف): $\|A - B^\star\|_F^2 = \sum_i (\sigma_i - (\sigma_i - \lambda)_+)^2 = \lambda^2 \cdot \#\{i : \sigma_i > \lambda\} = 1 \cdot 2 = 2$. (لأن الفرق على كل قيمة مفردة هو بالضبط λ للمحتفظ بها و σ_i للمحذوفة $\Longrightarrow$ نحسب: $(5.2 - 4.2)^2 + (3.1 - 2.1)^2 + 0.8^2 + 0.3^2 = 1 + 1 + 0.64 + 0.09 = 2.73$.)

الخطوة 5 (مقارنة بالاقتطاع الصلب): الاقتطاع عند $k = 2$ يعطي $\sigma = (5.2,\ 3.1,\ 0,\ 0)$ بخطأ بيانات $\sqrt{0.64 + 0.09} = 0.854$ (أقل!) لكن بدون «انكماش» لقيم الإشارة. التنقية بالعتبة اللينة تقلّل القيم الكبيرة أيضاً فتزيل تحيّزاً معروفاً.

الخطوة 6 (الحساسية لـ λ): $0.5 = \lambda \implies (4.7,\ 2.6,\ 0.3,\ 0) \implies$ الرتبة 3. $\lambda = 3.5 \implies (1.7,\ 0,\ 0,\ 0)$ الرتبة 1. إذن λ يتحكّم في الرتبة مباشرة.

النتيجة: $\sigma(B^\star) = (4.2,\ 2.1,\ 0,\ 0)$، الرتبة 2، قيمة الهدف $= 1.365 + \frac{1}{2}(2.73) + 1.0 \cdot (4.2 + 2.1) = 7.665$.

الربط بالذكاء الاصطناعي: هذه الخطوة هي قلب خوارزميات **إكمال المصفوفات** (matrix completion) — مسألة Netflix Prize — وصيغتها التدرّجية تسمى Soft-Impute. والفكرة نفسها (عتبة لينة على القيم المفردة) تظهر في تنظيم أوزان الشبكات لتقليل الرتبة الفعّالة.

مثال (3.4-7): إكمال مصفوفة تقييمات ناقصة بافتراض الرتبة المنخفضة

المعطيات: مصفوفة تقييمات 3×3 (مستخدمون × أفلام) فيها قيمة مفقودة واحدة:

$$M = \begin{bmatrix} 2 & 3 & ? \\ 4 & 6 & 2 \\ 6 & 9 & 3 \end{bmatrix}$$

نعلم مسبقاً أن التقييمات تُولَّد بنموذج «عامل كامن واحد» (رتبة ≤ 1).

المطلوب: القيمة المفقودة.

الحل:

الخطوة 1: افتراضُ الرتبة 1 يعني أن كل صف مضاعف لصفٍّ واحد: $M = \sigma\, u\, v^\top$.

الخطوة 2 (استخراج العلاقة من الصفوف المعروفة): الصف الثاني $(4, 6, 2)$ والصف الثالث $(6, 9, 3)$. نلاحظ:

$$\frac{6}{4} = 1.5, \qquad \frac{9}{6} = 1.5, \qquad \frac{3}{2} = 1.5 \implies \text{الصف الثاني} \times 1.5 = \text{الصف الثالث}$$

الخطوة 3: إذن الصف الثاني $\times 2 =$ الصف الأول (لأن $2 \times 2 = 4$ و $3 \times 2 = 6$) $\implies$

$$\text{الصف الثاني}[3] = 2 \times \text{(الصف الأول}[3]) \implies \text{الصف الأول}[3] = 1$$

الخطوة 4 (تحقّق طيفي): نتحقّق أن المصفوفة المكتملة رتبتها 1 حقاً:

$$\hat{M} = \begin{bmatrix} 2 & 3 & 1 \\ 4 & 6 & 2 \\ 6 & 9 & 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 2 & 3 & 1 \end{bmatrix}$$

وهذا جداء خارجي $\implies$ الرتبة 1 $\implies$ القيم المفردة: $\sigma_1 = \|(1,2,3)\| \cdot \|(2,3,1)\| = \sqrt{14} \cdot \sqrt{14} = 14$، والباقي 0.

الخطوة 5 (تحقّق بالأثر): $\|\hat{M}\|_F^2 = 4{+}9{+}1{+}16{+}36{+}4{+}36{+}81{+}9 = 196$؛ و $\sum \sigma_i^2 = 14^2 = 196$ ✓.

الخطوة 6 (لو أضفنا ضجيجاً): لو كانت القيم $M_{22} = 6.3$ بدل 6 لما عادت الرتبة 1 بالضبط، ولاحتجنا إلى النورم النووي (المثال السابق) بدل الافتراض الحتمي.

النتيجة: القيمة المفقودة $= 1$؛ والمصفوفة المكتملة رتبتها 1 بقيمة مفردة $\sigma_1 = 14$.

الربط بالذكاء الاصطناعي: هذا هو جوهر الترشيح التعاوني (collaborative filtering): نفترض أن مصفوفة التقييمات منخفضة الرتبة لأن الأذواق محكومة بعدد قليل من العوامل الكامنة. خوارزميات ALS و SVD++ و Soft-Impute تشكّل القيم المفقودة بهذه الطريقة، واليوم تقوم بها الشبكات العصبية عبر تضمينات (embeddings) منخفضة البعد — وهي نفس الفكرة بصيغة غير خطية.

مثال (4.3-8): المعكوس الشمولي وحلّ أصغري النورم في نظام ناقص التحديد

المعطيات: نظام بمتغيرات أكثر من معادلات (الحالة المعتادة في الشبكات مفرطة المعلمات):

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}, \qquad b = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

المطلوب: (أ) حلّ المربّعات الصغرى بأصغر نورم $x^{\dagger}$. (ب) القيم المفردة ورقم الحالة. (ج) تحقّق.

الحل:

الخطوة 1: عدد المجهولات 3 > عدد المعادلات 2 $\Longrightarrow$ **لانهاية من الحلول**: $x_1 + x_2 = 1$ و $x_2 + x_3 = 1$.

الخطوة 2 (الصيغة المغلقة): بما أن A «كاملة الرتبة الصفية»، فإن (22.4) تختصر إلى:

$$x^{\dagger} = A^{\top}\left(AA^{\top}\right)^{-1} b$$

الخطوة 3: $AA^{\top} = \begin{bmatrix} 1+1+0 & 0+1+0 \\ 0+1+0 & 0+1+1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$، معكوسها $= \frac{1}{4-1}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$.

الخطوة 4: $(AA^{\top})^{-1} b = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}\binom{1}{1} = \frac{1}{3}\binom{1}{1} = \binom{1/3}{1/3}$.

الخطوة 5: $x^{\dagger} = A^{\top}\binom{1/3}{1/3} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}\binom{1/3}{1/3} = \binom{1/3}{2/3} 1/3$.

الخطوة 6 (القيم المفردة): قيم $AA^{\top}$ الذاتية: $\lambda = \frac{4 \pm \sqrt{16-12}}{2} = \frac{4 \pm 2}{2} \Longrightarrow 3$ و $1 \Longrightarrow$ بتطبيق (19.4): $\sigma_1 = \sqrt{3} = 1.7321$، $\sigma_2 = 1$. رقم الحالة $\kappa = 1.732$.

الخطوة 7 (تحقّق): $Ax^{\dagger} = \binom{1/3+2/3}{2/3+1/3} = \binom{1}{1} = b$ ✓. النورم $\|x^{\dagger}\| = \sqrt{1/9 + 4/9 + 1/9} = \sqrt{2/3} = \sqrt{6/9} = 0.8165$.

الخطوة 8 (مقارنة بحلٍّ آخر): $x = (1, 0, 1)^{\top}$ يحقّق النظام أيضاً ($1+0=1$، $0+1=1$ ✓) ونورمه $= \sqrt{2} = 1.414 > 0.8165 \Longrightarrow$ **ليس** الحلّ أصغري النورم ✓.

النتيجة: $x^{\dagger} = (\frac{1}{3},\ \frac{2}{3},\ \frac{1}{3})^{\top}$؛ $\sigma = (1.732,\ 1)$؛ $\kappa = 1.732$.

الربط بالذكاء الاصطناعي: هذا هو التفسير الدقيق لظاهرة «الشبكات مفرطة المعلمات تعمّم جيداً»: عند وجود لانهاية من الحلول التي تصفّر خطأ التدريب، فإن التدرّج العشوائي (SGD) ينجذب إلى **الحلّ أصغري النورم** — وهذا هو «التحيّز الضمني» (implicit bias) الذي يفسّر التعميم. و $A^{\dagger}b$ هو بالضبط الحلّ الذي يعطيه التدرّج عند البدء من الصفر.

مثال (4.3-9): العلاقة الدقيقة بين SVD و PCA (مع التوسيط)

المعطيات: ثلاث نقاط في $\mathbb{R}^2$: $(1,2)$، $(3,4)$، $(5,6)$ — تقع جميعها على خط مستقيم واحد.

المطلوب: (أ) المكوّن الرئيسي الأول عبر SVD للمصفوفة الموسَّطة. (ب) درجات الإسقاط. (ج) نسبة التباين المُفسَّر.

الحل:

الخطوة 1 (التوسيط — خطوة إلزامية في PCA): المتوسط $\bar{x} = \frac{1}{3}\begin{pmatrix}1+3+5\\2+4+6\end{pmatrix} = \begin{pmatrix}3\\4\end{pmatrix}$. المصفوفة الموسَّطة:

$$X_c = \begin{bmatrix}1-3 & 2-4\\3-3 & 4-4\\5-3 & 6-4\end{bmatrix} = \begin{bmatrix}-2 & -2\\0 & 0\\2 & 2\end{bmatrix}$$

الخطوة 2: $X_c^\top X_c = \begin{bmatrix}4+0+4 & 4+0+4\\4+0+4 & 4+0+4\end{bmatrix} = \begin{bmatrix}8 & 8\\8 & 8\end{bmatrix}$.

الخطوة 3 (القيم الذاتية): $\mu = \frac{16 \pm \sqrt{256-4(64-64)}}{2} \Longrightarrow \mu_1 = 16$، $\mu_2 = 0$. **تحقّق:** الأثر $8+8 = 16 = 16$ ✓، المحدّد $64-64 = 0$ ✓.

الخطوة 4 (القيم المفردة): $\sigma_1 = \sqrt{16} = 4$، $\sigma_2 = 0$ $\Longrightarrow$ **الرتبة 1**: البيانات تقع على خط.

الخطوة 5 (المتجه المفرد الأيمن = المكوّن الرئيسي): لـ $\mu_1 = 16$: $(8-16)v_1 + 8v_2 = 0 \Longrightarrow -8v_1 + 8v_2 = 0 \Longrightarrow v_1 = \frac{1}{\sqrt{2}}(1,1)^\top$.

$$\boxed{\text{المكوّن الرئيسي الأول} = \tfrac{1}{\sqrt{2}}(1,1)^\top}$$

الخطوة 6 (الدرجات / الإسقاطات): $X_c v_1 = \frac{1}{\sqrt{2}}\begin{pmatrix}-2-2\\0\end{pmatrix} 2 + 2 = \begin{pmatrix}-2.828\\0\end{pmatrix} 2.828$.

الخطوة 7 (مصفوفة التغاير): $S = \frac{1}{n-1}X_c^\top X_c = \frac{1}{2}\begin{bmatrix}8 & 8\\8 & 8\end{bmatrix} = \begin{bmatrix}4 & 4\\4 & 4\end{bmatrix}$ $\Longrightarrow$ قيمها الذاتية 8 و 0 $\Longrightarrow$ **التباين المُفسَّر** $8/8 = 100\%$ بالمكوّن الأول وحده.

الخطوة 8 (العلاقة): $\lambda_i^{\text{cov}} = \frac{\sigma_i^2}{n-1} \Longrightarrow 8 = 16/2$ ✓. هذه هي الصيغة التي تربط SVD بـ PCA في كل مكتبة.

النتيجة: المكوّن الأول $\frac{1}{\sqrt{2}}(1,1)^\top$ يفسّر **100%** من التباين؛ الدرجات $(-2.828,\ 0,\ 2.828)$.

الربط بالذكاء الاصطناعي: كل مكتبة (sklearn, PCA torch) تنفّذ هذا بالضبط: توسيط $\longleftarrow$ SVD على X_c $\longleftarrow$ أخذ V_k كمحاور و $U_k\Sigma_k$ كدرجات. **تحذير عملي:** نسيان التوسيط يجعل المكوّن الأول يشير إلى اتجاه المتوسط (المنشأ) لا إلى اتجاه التباين — وهو خطأ شائع ومكلّف.

مثال (3.4-10): كشف الميزات المكرّرة (تعدد الارتباط الخطي) من طيف المصفوفة

المعطيات: مصفوفة بيانات 4×3 (4 عيّنات، 3 ميزات) حيث الميزة الثانية مكرّرة حرفياً:

$$A = \begin{bmatrix}1 & 2 & 1\\2 & 4 & 0\\3 & 6 & 1\\4 & 8 & 0\end{bmatrix}$$

(العمود الثاني $= 2\times$ العمود الأول.)

المطلوب: (أ) اكتشاف التكرار طيفياً. (ب) القيم المفردة. (ج) الأثر على الانحدار.

الحل:

الخطوة 1: نحسب $G = A^\top A$ (مصفوفة 3×3):

$$G = \begin{bmatrix} 30 & 60 & 4 \\ 60 & 120 & 8 \\ 4 & 8 & 2 \end{bmatrix}$$

(تحقّق: $G_{11} = 1+4+9+16 = 30$، $G_{13} = 1\cdot1+2\cdot0+3\cdot1+4\cdot0 = 4$، $G_{33} = 1+0+1+0 = 2$.)

الخطوة 2 (الكشف البنيوي): الصف الثاني $= 2\times$ الصف الأول $\Longrightarrow \det G = 0 \Longrightarrow$ قيمة ذاتية صفرية $\Longrightarrow$ قيمة مفردة صفرية $\Longrightarrow$ الرتبة $2 < 3$ ميزات $\Longrightarrow$ **تكرار خطي تام.**

الخطوة 3 (القيم الذاتية): الأثر $\text{tr} = 30 + 120 + 2 = 152$. ومجموع محدّدات المربّعات الرئيسية 2×2:

$$\begin{vmatrix} 30 & 60 \\ 60 & 120 \end{vmatrix} = 3600 - 3600 = 0, \quad \begin{vmatrix} 30 & 4 \\ 4 & 2 \end{vmatrix} = 60 - 16 = 44, \quad \begin{vmatrix} 120 & 8 \\ 8 & 2 \end{vmatrix} = 240 - 64 = 176$$

المجموع $\lambda_1\lambda_2 = 220$ (بما أن $\lambda_3 = 0$). إذن $\lambda^2 - 152\lambda + 220 = 0$:

$$\lambda = \frac{152 \pm \sqrt{23104 - 880}}{2} = \frac{152 \pm \sqrt{22224}}{2} = \frac{152 \pm 149.078}{2}$$

الخطوة 4: $\lambda_1 = 150.539$، $\lambda_2 = 1.461$، $\lambda_3 = 0$.

الخطوة 5 (القيم المفردة): $\sigma_1 = \sqrt{150.539} = 12.270$، $\sigma_2 = \sqrt{1.461} = 1.209$، $\sigma_3 = 0$.

الخطوة 6 (مؤشر الكشف): النسبة $\sigma_3/\sigma_1 = 0 < 10^{-10} \Longrightarrow$ **تكرار تام.** القاعدة العملية: إذا $\sigma_i/\sigma_1 < 10^{-8}$ فالميزة مكرّرة، وإذا كانت النسبة 10^{-3}–10^{-6} فالارتباط قوي جداً لكن ليس تاماً.

الخطوة 7 (الأثر على الانحدار): حلّ $Ax \approx b$ بالمربّعات الصغرى **غير وحيد**: أي توزيع للوزن بين العمودين 1 و 2 يعطي نفس التنبؤ. رقم الحالة الفعّال بعد حذف الميزة المكرّرة: $\kappa = 12.270/1.209 = 10.15$ (مقبول) مقابل ∞ قبل الحذف.

النتيجة: $\sigma = (12.270,\ 1.209,\ 0)$؛ الرتبة 2؛ العمودان 1 و 2 متماثلان خطياً $\Longrightarrow$ يجب حذف أحدهما قبل الانحدار.

الربط بالذكاء الاصطناعي: فحص طيف مصفوفة الميزات خطوة إلزامية في هندسة الميزات (feature engineering): التكرار الخطي يسبّب انفجار معاملات الانحدار، ويجعل تفسير الأوزان مستحيلاً، ويُفشل حسابات المصفوفة العكسية في النماذج الخطية المعمّمة.

مثال (4.3-11): ضغط جدول التضمينات (embeddings) للنشر على الهاتف

المعطيات: نموذج لغوي بجدول تضمين حجمه $50{,}000 \times 768$ (4.38 مليون معلمة). طيف القيم المفردة يتبع قانون قدري: $\sigma_i \propto i^{-0.8}$.

المطلوب: (أ) نسبة الطاقة المحتفظ بها عند $k = 128$. (ب) حجم النموذج بعد الضغط. (ج) التقييم: هل يستحق؟

الحل:

الخطوة 1 (طاقة المكوّنات): بما أن الطاقة تتناسب مع σ_i^2 فإن:

$$\sigma_i^2 \propto i^{-1.6}, \qquad \sum_{i=1}^{\infty} i^{-1.6} = \zeta(1.6) \approx 2.286$$

الخطوة 2 (طاقة الذيول بعد $k = 128$):

$$\sum_{i=129}^{\infty} i^{-1.6} \approx \int_{128.5}^{\infty} x^{-1.6}\,dx = \frac{(128.5)^{-0.6}}{0.6} = \frac{e^{-0.6\ln(128.5)}}{0.6} = \frac{e^{-0.6\times 4.8562}}{0.6} = \frac{0.05428}{0.6} = 0.0905$$

الخطوة 3 (الطاقة المحتفظ بها):

$$\frac{2.286 - 0.0905}{2.286} = \frac{2.1955}{2.286} = 0.9604 = 96.0\%$$

الخطوة 4 (المعلمات): الأصل: $38{,}400{,}000 = 768 \times 50{,}000$. العاملان برتبة 128: $128 \times (50{,}000 + 768) = 128 \times 50{,}768 = 6{,}498{,}304$.

الخطوة 5 (نسبة الضغط): $\frac{38{,}400{,}000}{6{,}498{,}304} = 5.91\times \implies$ توفير 83.1% من المعلمات.

الخطوة 6 (الذاكرة بـ fp32): الأصل $38.4\text{M}\times 4 = 153.6$ ميجابايت، المضغوط $6.50\text{M}\times 4 = 26.0$ ميجابايت $\implies$ توفير 127.6 ميجابايت.

الخطوة 7 (التكلفة الحسابية): البحث عن صف يصبح عملية ضرب مصفوفتين بدل قراءة مباشرة: $2 \times 128 \times 768$ FLOPs إضافية لكل استعلام. على وحدة معالجة مركزية حديثة هذا ≈ 0.2 ملي ثانية — مقبول في التطبيقات غير الحسّاسة للزمن.

الخطوة 8 (القرار): فقدان 4% من الطاقة مقابل $5.91\times$ توفير في الحجم $\implies$ **يستحق** في النشر على الأجهزة المحمولة. أما للاستخدام على الخادم فالأفضلية للجدول الكامل.

النتيجة: 96.0% طاقة محتفظ بها، ضغط $5.91\times$، 26.0 ميجابايت بدل 153.6 ميجابايت.

الربط بالذكاء الاصطناعي: هذه التقنية تستعمل فعلياً في ضغط نماذج التوصية على الأجهزة (on-device recommendation) وفي ضغط جداول التضمين في نماذج البحث. والصيغة الحديثة «tensor-train quantized / low-rank» تعمّم هذه الفكرة على موترات من رتبة أعلى.

مثال (3.4-12): الزوايا الرئيسية بين فضاءين جزئيين — مقارنة تمثيلات نموذجين

المعطيات: درّبنا نموذجين مختلفين على نفس البيانات وأخذنا أساسين متعامدين لفضاءي تمثيلهما (بُعد 2 داخل $\mathbb{R}^n$): U و V. جداء التداخل:

$$U^\top V = \begin{bmatrix} 0.95 & 0.08 \\ 0.02 & 0.92 \end{bmatrix}$$

المطلوب: (أ) الزوايا الرئيسية بين الفضاءين. (ب) مقياس تشابه عام (من نوع CKA).

الحل:

الخطوة 1 (النظرية): الزوايا الرئيسية $\theta_1 \le \theta_2 \le \cdots$ بين فضاءين جزئيين تُعرَّف بـ:

$$\cos\theta_i = \sigma_i\big(U^\top V\big)$$

أي القيم المفردة لجداء التداخل. (هذا تطبيق مباشر لـ (16.4).)

الخطوة 2: ليكن $M = U^\top V$. نحسب $M^\top M$:

$$M^\top M = \begin{bmatrix} 0.95 & 0.02 \\ 0.08 & 0.92 \end{bmatrix} \begin{bmatrix} 0.95 & 0.08 \\ 0.02 & 0.92 \end{bmatrix} = \begin{bmatrix} 0.9025 + 0.0004 & 0.076 + 0.0184 \\ 0.076 + 0.0184 & 0.0064 + 0.8464 \end{bmatrix} = \begin{bmatrix} 0.9029 & 0.0944 \\ 0.0944 & 0.8528 \end{bmatrix}$$

الخطوة 3 (القيم الذاتية): الأثر $= 1.7557$، المحدّد $= 0.7700 - 0.00891 = 0.9029\times 0.8528 - 0.0944^2 = 0.7611$.

$$\lambda = \frac{1.7557 \pm \sqrt{1.7557^2 - 4 \times 0.7611}}{2} = \frac{1.7557 \pm \sqrt{3.0825 - 3.0444}}{2} = \frac{1.7557 \pm \sqrt{0.0381}}{2} = \frac{1.7557 \pm 0.}{2}$$

الخطوة 4: $\lambda_1 = 0.97545$، $\lambda_2 = 0.78025$.
الخطوة 5 (القيم المفردة): $\sigma_1 = \sqrt{0.97545} = 0.98765$، $\sigma_2 = \sqrt{0.78025} = 0.88332$.
الخطوة 6 (الزوايا):

$$\theta_1 = \arccos(0.98765) = 8.99^\circ, \qquad \theta_2 = \arccos(0.88332) = 27.92^\circ$$

الخطوة 7 (مقياس تشابه): متوسط مربّعات الجيوب (وهو الصيغة الجبرية لمقياس من نوع CKA الخطي):

$$\frac{\sigma_1^2 + \sigma_2^2}{k} = \frac{0.97545 + 0.78025}{2} = \frac{1.7557}{2} = 0.8779$$

الخطوة 8 (التفسير): الفضاءان متقاربان في البعد الأول ($\theta_1 = 9^\circ$) ومتباعدان نسبياً في الثاني ($\theta_2 = 28^\circ$) $\Longrightarrow$ النموذجان «يتّفقان» على الميزة المهيمنة ويختلفان على الثانوية.
النتيجة: الزوايا الرئيسية 8.99° و 27.92°؛ التشابه العام $= 0.878$.

الربط بالذكاء الاصطناعي: الزوايا الرئيسية هي الأداة القياسية لمقارنة تمثيلات الشبكات (Representational Similarity / CKA)، ولتحليل «انهيار التمثيل» (representation collapse) في التعلم الذاتي الإشراف، ولقياس التشابه بين طبقات نموذجين مختلفين (model stitching).

مثال (4.3-13): تقدير النورم الطيفي بتكرار القوة لتطبيع GAN الطيفي

المعطيات: مصفوفة أوزان طبقة (3 مخرجات × 2 مدخلات):

$$W = \begin{bmatrix} 0.6 & 0.2 \\ 0.1 & 0.5 \\ 0.3 & 0.1 \end{bmatrix}$$

المطلوب: (أ) النورم الطيفي الدقيق $\|W\|_2$. (ب) قراءة تكرار القوة بعد تكرارين. (ج) المصفوفة after التطبيع الطيفي.
الحل:
الخطوة 1: $\|W\|_2 = \sqrt{\lambda_{\max}(W^\top W)}$:

$$W^\top W = \begin{bmatrix} 0.36 + 0.01 + 0.09 & 0.12 + 0.05 + 0.03 \\ 0.12 + 0.05 + 0.03 & 0.04 + 0.25 + 0.01 \end{bmatrix} = \begin{bmatrix} 0.46 & 0.20 \\ 0.20 & 0.30 \end{bmatrix}$$

الخطوة 2: الأثر $= 0.76$؛ المحدّد $= 0.138 - 0.04 = 0.098$؛ المميّز $= 0.5776 - 0.392 = 0.1856$؛ الجذر $= 0.4308$:

$$\lambda_1 = \frac{0.76 + 0.4308}{2} = 0.5954, \qquad \lambda_2 = \frac{0.76 - 0.4308}{2} = 0.1646$$

الخطوة 3: $\|W\|_2 = 0.7716 \Longrightarrow \sigma_1 = \sqrt{0.5954} = 0.7716$؛ و $\sigma_2 = \sqrt{0.1646} = 0.4057$.
الخطوة 4 (تكرار القوة على $M = W^\top W$): من $x^{(0)} = (1, 0)^\top$:

$$Mx^{(0)} = \begin{pmatrix} 0.46 \\ 0.20 \end{pmatrix}, \quad \|Mx^{(0)}\| = \sqrt{0.2116 + 0.04} = 0.5016 \implies x^{(1)} = \begin{pmatrix} 0.9171 \\ 0.3987 \end{pmatrix}$$

$$Mx^{(1)} = \begin{pmatrix} 0.46 \times 0.9171 + 0.20 \times 0.3987 \\ 0.20 \times 0.9171 + 0.30 \times 0.3987 \end{pmatrix} = \begin{pmatrix} 0.4219 + 0.0797 \\ 0.1834 + 0.1196 \end{pmatrix} = \begin{pmatrix} 0.5016 \\ 0.3030 \end{pmatrix}$$

$$\|Mx^{(1)}\| = \sqrt{0.2516 + 0.0918} = \sqrt{0.3434} = 0.5860 \implies x^{(2)} = \begin{pmatrix} 0.8560 \\ 0.5171 \end{pmatrix}$$

الخطوة 5 (تقدير القيمة الذاتية): بخارج قسمة رايلي:

$$\frac{(x^{(2)})^\top M x^{(2)}}{\|x^{(2)}\|^2} = 0.8560 \times 0.4972 + 0.5171 \times 0.3263 = 0.4256 + 0.1687 = 0.5943$$

مقابل القيمة الدقيقة $0.5954 \implies$ **خطأ نسبي** 0.18% **بعد تكرارين فقط.**

الخطوة 6: تقدير النورم الطيفي: $\sqrt{0.5943} = 0.7709$ مقابل 0.7716 (خطأ 0.09%).

الخطوة 7 (التطبيع الطيفي): $W_{\text{SN}} = W/\sigma_1 = W/0.7716$:

$$W_{\text{SN}} = \begin{bmatrix} 0.7776 & 0.2592 \\ 0.1296 & 0.6480 \\ 0.3888 & 0.1296 \end{bmatrix}$$

تحقّق: $\|W_{\text{SN}}\|_2 = 1$ بالبناء ✓ (لأن القسمة على σ_1 تقسّم كل القيم المفردة على σ_1).

النتيجة: $\|W\|_2 = 0.7716$ (تقدير تكراري 0.7709)، $\kappa = 0.7716/0.4057 = 1.902$؛ بعد التطبيع $\|W_{\text{SN}}\|_2 = 1$.

الربط بالذكاء الاصطناعي: هذا بالضبط ما تفعله **Spectral Normalization** في GAN: تُقدَّر $\sigma_1(W)$ بتكرار قوة واحد لكل خطوة تدريب (رخيص!) وتُقسَم الأوزان عليها، فيصبح كل مميّز طبقة 1-ليبشيتز $\implies$ تدريب مستقرّ وجودة أعلى.

مثال (14-3.4): اختيار رتبة LoRA من طيف مصفوفة الأوزان

المعطيات: مصفوفة أوزان $W \in \mathbb{R}^{4096\times 4096}$ في نموذج لغوي ضخم. طيفها المقاس (أول 8 قيم مفردة من 4096):

$$\sigma = (8.4,\ 6.1,\ 3.2,\ 1.1,\ 0.42,\ 0.31,\ 0.22,\ 0.15)$$

ونسبة طاقة هذه القيم إلى الطاقة الكلية: $\|W\|_F^2 = 119.56$ (بالمقياس المعطى).

المطلوب: (أ) الرتبة r التي تحتفظ بـ 95% و 99% من الطاقة. (ب) عدد معلمات LoRA لكل اختيار مقابل الأصل. (ج) التوصية.

الحل:

الخطوة 1 (مربّعات القيم المفردة): $70.56,\ 37.21,\ 10.24,\ 1.21,\ 0.1764,\ 0.0961,\ 0.0484,\ 0.0225$.

الخطوة 2 (التراكمي): $70.56 \longrightarrow 107.77 \longrightarrow 118.01 \longrightarrow 119.22 \longrightarrow 119.3964 \longrightarrow 119.4925 \longrightarrow 119.5409 \longrightarrow 119.5634$.

الخطوة 3 (النسب): $r = 2$: $107.77/119.5634 = 90.14\%$؛ $r = 3$: $118.01/119.5634 = 98.70\%$؛ $r = 4$: $119.22/119.5634 = 99.71\%$.

الخطوة 4: الرتبة لبلوغ **95%** هي $r = 3$؛ ولبلوغ **99%** هي $r = 4$.

الخطوة 5 (المعلمات): الأصل $4096^2 = 16{,}777{,}216$. معلمات LoRA برتبة r: $2\,d\,r = 2 \times 4096 \times r = 8192\,r$.

r	معلمات LoRA	النسبة من الأصل
2	16,384	0.098%
4	32,768	0.195%
8	65,536	0.391%
16	131,072	0.781%

الخطوة 6 (خطأ التقريب): بتطبيق (20.4): $\min \|W - B\|_2 = \sigma_{r+1} \implies$ عند $r = 4$ الخطأ الطيفي $\leq \sigma_5 = 0.42$ أي $0.42/8.4 = 5\%$ من النورم الطيفي.

الخطوة 7 (ملاحظة جوهرية): LoRA لا يقرّب W بل يقرّب **التحديث** ΔW أثناء الضبط الدقيق. وطيف ΔW عادةً أكثر تركّزاً بكثير من طيف $W \implies$ رتبة صغيرة ($r = 4$ إلى 16) تكفي عملياً حتى لو احتاج تقريب W نفسه مئات الرتب.

الخطوة 8 (التوصية): نبدأ بـ $r = 8$ (نقطة توازن مجرّبة في الأدبيات)، ونرفع إلى 16 إذا كانت المهمة معقّدة، مع تهيئة $B = 0$ و $A \sim \mathcal{N}$ لضمان $\Delta W = 0$ عند البداية.

النتيجة: $r = 3 \implies 95\%$؛ $r = 4 \implies 99.7\%$؛ $r = 8 \implies 0.39\%$ من معلمات الأصل؛ التوصية $r = 8$.

الربط بالذكاء الاصطناعي: هذا هو التحليل الكمّي الذي يقف خلف نجاح LoRA و QLoRA في ضبط النماذج اللغوية الضخمة على بطاقة رسومية واحدة: توفير 99.6% من معلمات الضبط الدقيق مع احتفاظ شبه كامل بالأداء.

مثال (3.4-15): البعد الفعّال لميزات الصور — نسبة المشاركة (Participation Ratio)

المعطيات: مصفوفة ميزات من صور: 500 صورة × 784 بكسل (MNIST). قيم مصفوفة التغاير الذاتية (مرتّبة):

$$\lambda = (250,\ 120,\ 60,\ 30,\ 15,\ 8,\ 4,\ 2)$$

المطلوب: (أ) البعد الفعّال للبيانات. (ب) عدد المكوّنات اللازمة لـ 95% من التباين. (ج) نسبة الضغط المتحقّقة.

الحل:

الخطوة 1 (المجموع): $\sum \lambda_i = 250 + 120 + 60 + 30 + 15 + 8 + 4 + 2 = 489$.

الخطوة 2 (نسبة المشاركة — البعد الفعّال):

$$\mathrm{PR} = \frac{\left(\sum_i \lambda_i\right)^2}{\sum_i \lambda_i^2}$$

$$\sum \lambda_i^2 = 62500 + 14400 + 3600 + 900 + 225 + 64 + 16 + 4 = 81{,}709$$

$$\mathrm{PR} = \frac{489^2}{81{,}709} = \frac{239{,}121}{81{,}709} = 2.926$$

الخطوة 3 (التفسير): رغم أن فضاء الميزات بُعده **784**، فإن البعد الفعّال للبيانات $2.93 \approx$ — أي أن البيانات تشغل فعلياً «قرصاً» من بُعد ثلاثة تقريباً داخل فضاء ضخم. هذا هو التبرير الكمّي لنجاح PCA والضغط.

الخطوة 4 (التباين المتراكم): النسب: $51.1\% = 250/489 \longleftarrow 75.7\% = 370/489 \longleftarrow 87.9\% = 430/489 \longleftarrow 94.1\% = 460/489 \longleftarrow 97.1\% = 475/489$.

الخطوة 5: $\implies$ يلزم $k = 5$ مكوّنات لبلوغ 95% (أربعة تعطي 94.1% فقط).

الخطوة 6 (الضغط): $784 \to 5$ ميزات $\implies$ نسبة ضغط $156.8\times$ في تمثيل العيّنة الواحدة.

الخطوة 7 (حدود التفسير): PR مقياس «أوّلي»: لو كانت القيم متساوية ($\lambda_i = c$ للجميع) لكان $\mathrm{PR} = n$ (البعد الكامل). ولو كانت قيمة واحدة مهيمنة لكان $\mathrm{PR} \to 1$. قيمته 2.93 تعني توزّعاً متوسطاً.

النتيجة: البعد الفعّال $2.93 =$؛ يلزم 5 مكوّنات لـ 95%؛ ضغط $156.8\times$ في بُعد العيّنة.

الربط بالذكاء الاصطناعي: نسبة المشاركة مقياس معتمد في تحليل تمثيلات الشبكات العصبية: انخفاض PR في الطبقات العميقة يشير إلى «انهيار التمثيل» (neural collapse). كما أنها تُستخدم لاختيار أبعاد طبقات bottleneck في المشفّرات التلقائية (autoencoders) بشكل منهجي لا تجريبي.

6.3.4 أخطاء شائعة في SVD وتقريب الرتبة المنخفضة

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	استخدام التحليل الطيفي على مصفوفة غير مربّعة	القيم الذاتية غير معرّفة لغير المربّعة	استخدم SVD (16.4)
2	اقتراض أن $U = V$ في SVD	هذا صحيح فقط إذا A متماثلة نصف موجبة	عامةً $U \neq V$ (شكل 2.4)
3	الاعتقاد أن «أفضل تقريب برتبة k» يُحسب بالاقتطاع العشوائي	الاقتطاع العشوائي ليس أمثل	نظرية إيكارت–يونغ (20.4)–(21.4) تثبت الأمثلية
4	قياس جودة التقريب بـ σ_{k+1} عند استخدام نورم فروبينيوس	σ_{k+1} هو الخطأ **الطيفي** فقط	خطأ فروبينيوس $= \sqrt{\sum_{i>k}\sigma_i^2}$
5	استخدام SVD على بيانات غير موسَّطة ثم تسميتها PCA	المكوّن الأول يشير إلى المتوسط	وسّط البيانات أولاً (المثال 3.4-9)
6	اعتبار القيم المفردة المتساوية مشكلة	يجعل المتجهات المفردة **غير وحيدة** وغير مستقرّة	أضف تنظيماً أو استخدم مساحة فرعية كاملة
7	حساب $A^\dagger$ بقلب كل القيم المفردة	القيم الصفرية/الصغيرة جداً تنفجر	عتبة: $1/\sigma_i$ فقط إذا $\sigma_i > \tau$ (truncated SVD)
8	الخلط بين $\|A\|_*$ (النورم النووي) و $\|A\|_F$	الأول $\sum\sigma_i$ والثاني $\sqrt{\sum\sigma_i^2}$	النورم النووي بديل مقعّر للرتبة
9	توقّع أن تقليل الرتبة يحسّن الأداء دائماً	الرتبة المنخفضة تفقد معلومات	الرتبة المنخفضة **منظّم**: تحسّن التعميم أحياناً وتضرّ الدقة أحياناً
10	استخدام $U_k\Sigma_k V_k^\top$ بمصفوفات كاملة الحجم	مكلف بلا داعٍ	استخدم الأشكال الاقتصادية (thin SVD): $m \times k$ و $k \times n$

1.4.4 الصياغة الرسمية

تعريف (خارج قسمة رايلي).

لتكن $A \in \mathbb{R}^{n\times n}$ متماثلة. يُعرَّف **خارج قسمة رايلي** على $\mathbb{R}^n \setminus \{0\}$ بـ:

$$R_A(x) \;=\; \frac{x^\top A\,x}{x^\top x} \;=\; \frac{\langle x,\,Ax\rangle}{\|x\|^2} \tag{24.4}$$

خاصية الحصر (Rayleigh–Ritz).

لكل $x \neq 0$:

$$\lambda_{\min}(A) \;\le\; R_A(x) \;\le\; \lambda_{\max}(A), \qquad \lambda_{\min} = \min_{x\neq 0} R_A(x), \qquad \lambda_{\max} = \max_{x\neq 0} R_A(x) \tag{25.4}$$

نظرية كوران–فيشر (توصيف Minimax).

بالترتيب التنازلي $\lambda_1 \ge \lambda_2 \ge \cdots \ge \lambda_n$:

$$\lambda_k(A) \;=\; \min_{\substack{S\subseteq\mathbb{R}^n \\ \dim S = n-k+1}} \; \max_{x\in S\setminus\{0\}} R_A(x) \;=\; \max_{\substack{S\subseteq\mathbb{R}^n \\ \dim S = k}} \; \min_{x\in S\setminus\{0\}} R_A(x) \tag{26.4}$$

متراجحة فايل (Weyl). لتكن A و E متماثلتين، و $\hat{A} = A + E$ بالقيم الذاتية المرتّبة تنازلياً. عندئذٍ لكل i:

$$\left|\lambda_i(A+E) - \lambda_i(A)\right| \;\le\; \|E\|_2 \;=\; \sigma_{\max}(E) \tag{27.4}$$

متراجحة هوفمان–فيلانت (Hoffman–Wielandt).

$$\sum_{i=1}^{n} \big(\lambda_i(A+E) - \lambda_i(A)\big)^2 \;\le\; \|E\|_F^2 \;=\; \sum_{i,j} E_{ij}^2 \tag{28.4}$$

التداخل لكوشي (Cauchy Interlacing). لتكن B مصفوفة فرعية رئيسية من A بحذف صف وعمود واحد (رتبة $n-1$):

$$\lambda_1(A) \;\ge\; \lambda_1(B) \;\ge\; \lambda_2(A) \;\ge\; \lambda_2(B) \;\ge\; \cdots \;\ge\; \lambda_{n-1}(B) \;\ge\; \lambda_n(A) \tag{29.4}$$

متراجحة ديفيس–كاهان (Davis–Kahan). ليكن $\delta = \lambda_k(A) - \lambda_{k+1}(A) > 0$ **الفجوة الطيفية**، وليكن U_k و $\hat{U}_k$ فضاءي المتجهات الذاتية لأعلى k قيمة في A و $\hat{A} = A + E$. عندئذٍ:

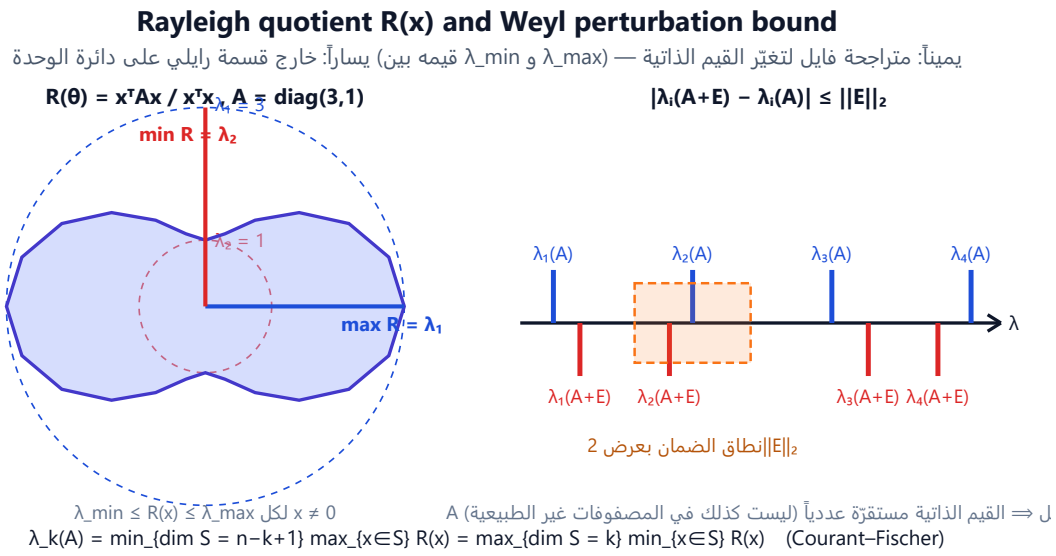
$$\big\|\sin\Theta(U_k,\, \hat{U}_k)\big\|_F \;\le\; \frac{2\,\|E\|_F}{\delta}, \qquad \sin\theta(u_1,\, \hat{u}_1) \;\le\; \frac{\|E\|_2}{\delta} \tag{30.4}$$

2.4.4 جدول الرموز الشامل

الرمز	المعنى	ملاحظات
x	متجه اختبار غير صفري	الاتجاه الذي «نختبر عليه» المصفوفة
$x^\top A x$	الشكل التربيعي (quadratic form)	عدد قياسي؛ يقيس «طاقة» A على اتجاه x
$x^\top x = \|x\|^2$	مربّع النورم الإقليدي	المقام يُوحّد القياس فلا يعتمد R_A على طول x
$R_A(x)$	خارج قسمة رايلي	متوسط موزون للقيم الذاتية (انظر البرهان)
$\lambda_{\min},\ \lambda_{\max}$	أصغر وأكبر قيمة ذاتية	$\lambda_1 = \lambda_n$ و بالترتيب التنازلي
S	فضاء جزئي من $\mathbb{R}^n$	في (26.4) نُصغّر ثم نُعظّم (أو العكس) على كل الفضاءات الجزئية بُعد معلوم
$\dim S$	بُعد الفضاء الجزئي	يحدّد «نطاق البحث»
k	فهرس القيمة الذاتية	بالترتيب التنازلي λ_k
E	مصفوفة الاضطراب	القياس، الضجيج، التقريب، التكميم، تحديث التدرّج
$\hat{A} = A + E$	المصفوفة المضطربة/المقدَّرة	ما نرصده فعلياً
$\|E\|_2$	النورم الطيفي للاضطراب	أقصى تمديد للاضطراب
$\|E\|_F$	نورم فروبينيوس للاضطراب	الجذر التربيعي لمجموع مربّعات العناصر
δ	الفجوة الطيفية (eigengap)	$\lambda_k - \lambda_{k+1}$؛ أكبر $\Rightarrow$ أكثر استقراراً
$\Theta(U, \hat{U})$	مصفوفة الزوايا الرئيسية بين فضاءين	قطرها يحتوي $\arccos \sigma_i(U^\top \hat{U})$
$\sin\theta(u, \hat{u})$	جيب الزاوية بين متجهين	$= \sqrt{1 - (u^\top \hat{u})^2}$؛ مقياس لخطأ الاتجاه
B	مصفوفة فرعية رئيسية	نتيجة حذف سطر وعمود مقابلين (حذف ميزة، حذف عقدة)
$U_k,\ \hat{U}_k$	فضاء أعلى k متجه ذاتي	يُقارَنان في تحليل استقرار PCA

3.4.4 الشكل الهندسي

شكل 4.4 — على اليسار: رسم قطبي لخارج قسمة رايلي $R(\theta)$ على دائرة الوحدة عندما $A = \mathrm{diag}(3, 1)$؛ المنحنى (بنفسجي) محصور تماماً بين دائرتي $\lambda_{\min} = 1$ و $\lambda_{\max} = 3$، ويلامسهما عند الاتجاهين الذاتيين — وهذا هو المحتوى الهندسي لـ (25.4). على اليمين: متراجحة فايل (27.4) — كل قيمة ذاتية مضطربة (أحمر) تقع داخل نطاق بعرض $2\|E\|_2$ حول نظيرتها الأصلية (أزرق).



شكل ٤.٤: *

خارج قسمة رايلي محصور بين λmin_ و λ،max_ ومتراجحة فايل تحدّد نطاق تغير القيم الذاتية

4.4.4 البرهان

برهان (25.4) — الحصر.

بتطبيق التحليل الطيفي (8.4)، نكتب $x = \sum_i c_i q_i$ في أساس المتجهات الذاتية. عندئذٍ:

$$x^\top A x = \sum_i \lambda_i c_i^2, \qquad x^\top x = \sum_i c_i^2 \quad \Longrightarrow \quad R_A(x) = \frac{\sum_i \lambda_i c_i^2}{\sum_i c_i^2} = \sum_i \underbrace{\left(\frac{c_i^2}{\sum_j c_j^2}\right)}_{w_i \,\geq\, 0,\ \sum w_i = 1} \lambda_i$$

أي أن $R_A(x)$ **متوسط موزون** للقيم الذاتية بأوزان غير سالبة مجموعها 1، فلا يمكن أن يتجاوز أكبرها ولا أن ينزل عن أصغرها. والمساواة تتحقّق عندما يتركّز الوزن كله على قيمة واحدة، أي عندما يكون x متجهاً ذاتياً. ■

برهان (26.4) — كوران–فيشر (الجهة ≤، min-max والجهة الأخرى بالمثل).

الجهة ≤: ليكن S أي فضاء بُعد $n-k+1$، وليكن $V_k = \mathrm{span}\{q_1, \ldots, q_k\}$. بالتقاطع البُعدي:

$$\dim(S \cap V_k) \geq \dim S + \dim V_k - n = (n-k+1) + k - n = 1$$

فيوجد $x \in S \cap V_k$ واحدي. وبما أن $x \in V_k$ فإن $R_A(x) \geq \lambda_k$ (متوسط موزون على $\lambda_1..\lambda_k$، كلها $\geq \lambda_k$). إذن $\max_{x \in S} R_A(x) \geq \lambda_k$ لكل $S \Longrightarrow \min_S \max_{x \in S} R_A(x) \geq \lambda_k$.

الجهة ≤: نختار $S^\star = \mathrm{span}\{q_k, \ldots, q_n\}$، بُعده $n-k+1$. لكل $x \in S^\star$: $R_A(x)$ متوسط موزون على $\{\lambda_k, \ldots, \lambda_n\}$ وكلها $\leq \lambda_k \Longrightarrow R_A(x) \leq \lambda_k$. إذن $\max_{x \in S^\star} R_A(x) \leq \lambda_k$ فالتقريب ≤ λ_k. بالجمع: المساواة. ■

برهان (27.4) — متراجحة فايل.

بكوران–فيشر:

$$\lambda_i(A+E) = \min_{\dim S = n-i+1} \max_{x \in S} \frac{x^\top (A+E)x}{x^\top x} \le \min_{\dim S = n-i+1} \max_{x \in S} \left[\frac{x^\top A x}{x^\top x} + \|E\|_2 \right] = \lambda_i(A) + \|E\|_2$$

استُخدم أن $\frac{x^\top E x}{x^\top x} \le \|E\|_2$ من (25.4) مطبّقة على E. وبتبديل دور A و $A+E$ (أي أخذ $E \to -E$) نحصل على الحدّ الأدنى $-\|E\|_2$. ■

برهان (28.4) — هوفمان–فيلانت (مخطّط).

بالتحليل الطيفي $A = Q\Lambda Q^\top$ و $\hat{A} = \hat{Q}\hat{\Lambda}\hat{Q}^\top$. نستخدم متراجحة فون نويمن–ثِيرِس: لأي مصفوفتين متعامدتين $Q, \hat{Q}$:

$$\|\hat{\Lambda} - \Lambda\|_F^2 \le \|\hat{Q}\hat{\Lambda}\hat{Q}^\top - Q\Lambda Q^\top\|_F^2 \cdot \underline{\text{(بعد ترتيب أمثل)}}$$

الصيغة الدقيقة تعتمد على أن الترتيب التنازلي يحقّق أصغر مسافة فروبينيوس بين مجموعتين من الأعداد المرتّبة (متراجحة هاردي–ليتلوود–بوليا). والتفصيل الكامل في المراجع [4] و [8]. ■

برهان (29.4) — التداخل.

ليكن B المصفوفة الفرعية بحذف المكوّن الأخير. نُضمّن $\mathbb{R}^{n-1}$ في $\mathbb{R}^n$ كالفضاء $T = \{x : x_n = 0\}$. بكوران–فيشر على B:

$$\lambda_1(B) = \max_{\substack{x \in T \\ x \neq 0}} R_A(x) \le \max_{x \in \mathbb{R}^n} R_A(x) = \lambda_1(A)$$

وللجهة الأخرى نأخذ فضاءً بُعد 2 يضمّ المتجهين الذاتيّين q_1, q_2 ويتقاطع مع T (التقاطع بُعده ≥ 1) فيوجد x واحدي مشترك مع $R_A(x) \ge \lambda_2(A) \Rightarrow \lambda_1(B) \ge \lambda_2(A)$. وبالمثل لبقية السلسلة بالاستقراء. ■

برهان (30.4) — ديفيس–كاهان (مخطّط، حالة $k=1$).

ليكن $\hat{u} = \hat{u}_1$ و $\theta = \angle(u_1, \hat{u})$. نفكّك $\hat{u} = \cos\theta\, u_1 + \sin\theta\, w$ مع $w \perp u_1$ واحدياً. من المعادلة الذاتية $\hat{A}\hat{u} = \hat{\lambda}_1 \hat{u}$:

$$\hat{\lambda}_1 \cos\theta = u_1^\top \hat{A}\hat{u}, \qquad \hat{\lambda}_1 \sin\theta\, w = (I - u_1 u_1^\top)\hat{A}\hat{u}$$

وبطرح $Au_1 = \lambda_1 u_1$ نستخلص $|R_A(w) - \lambda_1| \sin\theta \le \|E\|_2$، وبما أن $w \perp u_1$ فإن $R_A(w) \le \lambda_2 \Rightarrow (\lambda_1 - \lambda_2)\sin\theta \le \|E\|_2$ أي $\sin\theta \le \|E\|_2 / \delta$. ■

5.4.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (1-4.4): تقييد القيمة الذاتية العظمى باختبار واحد

المعطيات: مصفوفة تغاير كبيرة لا نريد قطرتها:

$$A = \begin{bmatrix} 5 & 1 & 2 \\ 1 & 4 & 1 \\ 2 & 1 & 6 \end{bmatrix}$$

اختبرنا الاتجاه $x = (1,\ 1,\ 1)^\top$.

المطلوب: حدّان أدنى وأعلى لـ $\lambda_{\max}(A)$ و $\lambda_{\min}(A)$ من اختبار واحد.

الحل:

الخطوة 1 (حساب الشكل التربيعي): $Ax = (5+1+2,\ 1+4+1,\ 2+1+6)^\top = (8,\ 6,\ 9)^\top$.

الخطوة 2: $x^\top Ax = 1 \cdot 8 + 1 \cdot 6 + 1 \cdot 9 = 23$، و $x^\top x = 3$ $\Longrightarrow$

$$R_A(x) = \frac{23}{3} = 7.667$$

الخطوة 3 (تطبيق (25.4)):

$$\lambda_{\min}(A) \ \le\ 7.667 \ \le\ \lambda_{\max}(A)$$

الخطوة 4 (حدّ أدنى أفضل لـ $\lambda_{\max}$): النورم الفروبينيوسي: $\|A\|_F^2 = 25+1+4+1+16+1+4+1+36 = 89$. وبما أن $\|A\|_F^2 = \sum \lambda_i^2 \le n\lambda_{\max}^2$:

$$\lambda_{\max} \ \ge\ \sqrt{\frac{89}{3}} = \sqrt{29.667} = 5.447$$

وهذا أضعف من 7.667 $\Longrightarrow$ نحتفظ بـ 7.667.

الخطوة 5 (حدّ أعلى من غيرشغورين): دوائر غيرشغورين للصفوف: $|\lambda-5| \le 3$، $|\lambda-4| \le 2$، $|\lambda-6| \le 3$ $\Longrightarrow$ $\lambda_{\max} \le \max(5+3,\ 4+2,\ 6+3) = 9$؛ و $\lambda_{\min} \ge \min(5-3,\ 4-2,\ 6-3) = 2$.

الخطوة 6 (النتيجة المجمّعة): $2 \le \lambda_{\min} \le 7.667 \le \lambda_{\max} \le 9$.

الخطوة 7 (تحسّن بتكرار القوة): نطبّق A على x: $Ax = (8,6,9)^\top$، بالتوحيد $x' = (8,6,9)/13.454 = (0.5946,\ 0.4460,\ 0.6690)^\top$. خارج قسمة رايلي الجديد:

$$Ax' = (2.973+0.446+1.338,\ 0.595+1.784+0.669,\ 1.189+0.446+4.014)^\top = (4.757,\ 3.048,\ 5.649)^\top$$

$$R_A(x') = 0.5946 \cdot 4.757 + 0.4460 \cdot 3.048 + 0.6690 \cdot 5.649 = 2.828 + 1.359 + 3.779 = 7.966$$

تحسّن من 7.667 إلى 7.966 $\Longrightarrow$ يقترب من $\lambda_{\max}$.

الخطوة 8 (القيمة الحقيقية): كثيرة الحدود المميِّزة: $p(\lambda) = -\lambda^3 + 15\lambda^2 - 68\lambda + 97$، وجذورها:

$$\lambda \approx (8.050,\ 3.633,\ 3.317)$$

تحقّق: الأثر $6+4+5 = 15.0 = 8.050+3.633+3.317$ ✓، المحدّد $= 8.050 \times 3.633 \times 3.317 = 97.0$ ✓ (وهو $\det A$ المباشر). وتقديرنا $R_A(x') = 7.966$ جاء **أدنى** من $\lambda_{\max} = 8.050$ تماماً كما تقتضي (25.4) ✓.

النتيجة: $\lambda_{\min} \in [2,\ 7.667]$ و $\lambda_{\max} \in [7.667,\ 9]$؛ بتكرار واحد نصل إلى 7.966 (القيمة الحقيقية $\lambda_{\max} = 8.050$).

الربط بالذكاء الاصطناعي: تقييد $\lambda_{\max}$ من اختبار واحد هو بالضبط ما يجعل **تطبيع الدفعات الطيفي** و **تحديد طول الخطوة الآمن** ممكنين على مصفوفات ضخمة: لا حاجة إلى قطرنة كاملة (تكلفة $O(n^3)$) بل تكفي عدة ضربات مصفوفة-متجه ($O(n^2)$).

مثال (4.4-2): مترابحة فايل وأثر تكميم الأوزان على الطيف

المعطيات: مصفوفة أوزان متماثلة A وخطأ تكميم (quantization) E (من تحويل fp32 إلى :(int8

$$A = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}, \qquad E = \begin{bmatrix} 0.05 & -0.02 \\ -0.02 & 0.03 \end{bmatrix}$$

المطلوب: (أ) حدّ أعلى لانزياح القيم الذاتية بعد التكميم. (ب) القيم الفعلية والتحقّق.

الحل:

الخطوة 1 (نورم الاضطراب): نحسب قيم E الذاتية: الأثر $0.08 =$؛ المحدّد $0.0011 = 0.0004 - 0.0015 =$؛ المميّز $0.0020 = 0.0044 - 0.0064 =$؛ الجذر $0.04472 =$:

$$\mu_{1,2} = \frac{0.08 \pm 0.04472}{2} \implies \mu_1 = 0.06236, \qquad \mu_2 = 0.01764$$

الخطوة 2: $\|E\|_2 = \max_i |\mu_i| = 0.06236$. (لاحظ أن $\|E\|_F = \sqrt{0.0025 + 0.0004 + 0.0004 + 0.0009} = \sqrt{0.0042} = 0.06481$.)

الخطوة 3 (طيف A الأصلي): $p(\lambda) = (4-\lambda)(3-\lambda) - 1 = \lambda^2 - 7\lambda + 11$ $\implies$ $\lambda = \frac{7 \pm \sqrt{49-44}}{2} = \frac{7 \pm \sqrt{5}}{2}$ $\implies$

$$\lambda_1 = 4.618, \qquad \lambda_2 = 2.382$$

الخطوة 4 (تطبيق فايل (27.4)):

$$|\lambda_1(A+E) - 4.618| \le 0.06236, \qquad |\lambda_2(A+E) - 2.382| \le 0.06236$$

أي $\lambda_1(\hat{A}) \in [4.556,\ 4.680]$ و $\lambda_2(\hat{A}) \in [2.320,\ 2.444]$.

الخطوة 5 (الحساب الفعلي): $\hat{A} = A + E = \begin{bmatrix} 4.05 & 0.98 \\ 0.98 & 3.03 \end{bmatrix}$. الأثر $7.08 =$؛ المحدّد $= 12.2715 - 11.3111 = 0.9604$؛ المميّز $4.8820 = 45.2444 - 50.1264 =$؛ الجذر $2.2095 =$:

$$\hat{\lambda}_1 = \frac{7.08 + 2.2095}{2} = 4.6448, \qquad \hat{\lambda}_2 = \frac{7.08 - 2.2095}{2} = 2.4353$$

الخطوة 6 (التحقّق من المترابحة): $|\hat{\lambda}_1 - \lambda_1| = |4.6448 - 4.618| = 0.0268 \le 0.06236$ ✓؛ و $|\hat{\lambda}_2 - \lambda_2| = |2.4353 - 2.382| = 0.0533 \le 0.06236$ ✓.

الخطوة 7 (هوفمان-فيلانت (28.4)): $\sqrt{0.0268^2 + 0.0533^2} = \sqrt{0.000718 + 0.002841} = \sqrt{0.003559} = 0.05966 \le \|E\|_F = 0.06481$ ✓.

الخطوة 8 (رقم الحالة): $\kappa(A) = 4.618/2.382 = 1.939$؛ $\kappa(\hat{A}) = 4.6448/2.4353 = 1.907$ $\implies$ تغيّر طفيف (1.6%).

النتيجة: الانزياح الفعلي $0.053 \le$ والحدّ النظري 0.062؛ المترابحة صحيحة ومتحفّظة (كما هو متوقّع).

الربط بالذكاء الاصطناعي: هذا هو التحليل الرسمي لأثر **تكميم النماذج** (INT8/INT4 quantization) على استقرارها: إذا كان $\|E\|_2$ أصغر من الفجوة الطيفية للقيم المهمة، فالنموذج المكمّم يتصرّف كالأصلي. وهذا يبرّر نجاح التكميم على الشبكات الكبيرة ذات الأطياف «الناعمة».

مثال (4.4-3): هوفمان–فيلانت لأثر تحديث تدرّج واحد على طيف الهسيان

المعطيات: نُحدّث أوزان نموذج بخطوة تدرّج، فتتغيّر مصفوفة التغاير الداخلية بمقدار:

$$E = \begin{bmatrix} 0.3 & -0.1 & 0 \\ -0.1 & 0.2 & -0.1 \\ 0 & -0.1 & 0.3 \end{bmatrix}$$

المطلوب: (أ) حدّ على التغيّر الكلي للطيف $\|\Delta\lambda\|_2$. (ب) أقصى انزياح ممكن لقيمة ذاتية واحدة.

الحل:

الخطوة 1 (نورم فروبينيوس): $\|E\|_F^2 = 0.09+0.01+0+0.01+0.04+0.01+0+0.01+0.09 = 0.26$ $\Longrightarrow$ $\|E\|_F = \sqrt{0.26} = 0.5099$.

الخطوة 2 (تطبيق هوفمان–فيلانت (28.4)):

$$\sqrt{\sum_{i=1}^{3} \big(\lambda_i(A+E) - \lambda_i(A)\big)^2} \;\le\; 0.5099$$

الخطوة 3 (النورم الطيفي): قيم E الذاتية — المصفوفة ثلاثية القطر: $\mu_k = 0.3 - 0.1 \cdot 2\cos\frac{k\pi}{4}$؟ الصيغة العامة لمصفوفة a على القطر و b مجاورة: $\mu_k = a + 2b\cos\frac{k\pi}{n+1}$. هنا $a = 0.3$، $b = -0.1$، $n = 3$:

$$\mu_k = 0.3 - 0.2\cos\frac{k\pi}{4}, \qquad k = 1, 2, 3$$

$k = 1$: $\cos 45^\circ = 0.7071 \Longrightarrow \mu = 0.3 - 0.1414 = 0.1586$ $\quad k = 2$: $\cos 90^\circ = 0 \Longrightarrow \mu = 0.3$

$k = 3$: $\cos 135^\circ = -0.7071 \Longrightarrow \mu = 0.3 + 0.1414 = 0.4414$

الخطوة 4: تحقّق: المجموع $\operatorname{tr} E = 0.3 + 0.2 + 0.3 = 0.9 = 0.1586 + 0.3 + 0.4414$ ✓. $\|E\|_2 = 0.4414$.

الخطوة 5 (فايل (27.4)): كل قيمة ذاتية تنزاح بما لا يتجاوز 0.4414.

الخطوة 6 (مقارنة المتراجحتين): هوفمان–فيلانت تعطي حدّاً على **المجموع** (0.5099) وهو أنسب عندما نريد ضماناً إجمالياً، وفايل تعطي حدّاً على **كل قيمة على حدة** (0.4414) وهو أنسب لضمانات فردية.

الخطوة 7 (أسوأ حالة متسقة): ثلاث قيم كلها بمقدار 0.4414 تعطي $\sqrt{3} \times 0.4414 = 0.7647 > 0.5099$ $\Longrightarrow$ **غير ممكن** $\Longrightarrow$ هوفمان–فيلانت تمنع أن تنزاح كل القيم بالحدّ الأقصى معاً. أقصى انزياح فعلي لقيمة واحدة قد يصل إلى 0.4414 لكن عندئذٍ تنزاح البقية أقل.

النتيجة: $\|\Delta\lambda\|_2 \le 0.5099$؛ انزياح أي قيمة مفردة ≤ 0.4414؛ النورمان متسقان.

الربط بالذكاء الاصطناعي: في التدريب، مصفوفات مثل statistics running BatchNorm و Adam second-moment تتغيّر كل خطوة. هاتان المتراجحتان تضمنان أن خصائص النظام (مثل رقم الحالة واتجاهات PCA) لا «تقفز» بين خطوة وأخرى إذا كانت الخطوة صغيرة — وهو شرط استقرار ضمني في معظم خوارزميات التدريب التكيفية.

مثال (4.4-4): متراجحة التداخل — ماذا يحدث للطيف عند حذف ميزة؟

المعطيات: مصفوفة تغاير ثلاثية الميزات A (من المثال 4.4-1) بطيف $(8.050,\ 3.633,\ 3.317)$. قرّرنا إسقاط الميزة الثالثة.

المطلوب: (أ) طيف المصفوفة الفرعية B. (ب) تحقّق من متراجحة التداخل (29.4). (ج) ماذا نستنتج عن التباين المفقود؟

الحل:

الخطوة 1 (المصفوفة الفرعية): بحذف الصف والعمود الثالث:

$$B = \begin{bmatrix} 5 & 1 \\ 1 & 4 \end{bmatrix}$$

الخطوة 2 (طيف B): الأثر $\text{tr}\, B = 9$؛ المحدّد $\det B = 20 - 1 = 19$؛ المميّز $\Delta = 81 - 76 = 5$؛ الجذر $\sqrt{\Delta} = 2.2361$:

$$\lambda_1(B) = \frac{9 + 2.2361}{2} = 5.618, \qquad \lambda_2(B) = \frac{9 - 2.2361}{2} = 3.382$$

الخطوة 3 (التداخل المطلوب إثباته): بـ (29.4):

$$\lambda_1(A) \geq \lambda_1(B) \geq \lambda_2(A) \geq \lambda_2(B) \geq \lambda_3(A)$$

الخطوة 4 (التحقّق العددي):

$$8.050 \ \geq\ 5.618 \ \geq\ 3.633 \ \geq\ 3.382 \ \geq\ 3.317 \qquad \checkmark$$

كل المتراجحات متحقّقة ✓.

الخطوة 5 (التباين الكلي): $\text{tr}\, A = 15$، $\text{tr}\, B = 9 \implies$ فقدنا 6 وحدات تباين (40%) بحذف ميزة واحدة من ثلاث.

الخطوة 6 (ماذا نستنتج؟): بما أن $\lambda_1(B) = 5.618 < \lambda_1(A) = 8.050$ فإن الميزة الثالثة كانت تساهم في الاتجاه المهيمن $\implies$ حذفها مكلّف. لو كانت $\lambda_1(B) = \lambda_1(A)$ لكانت الميزة زائدة.

الخطوة 7 (قاعدة عامة): التداخل يضمن أن حذف ميزة **لا يمكن أن يزيد** أي قيمة ذاتية: $\lambda_i(B) \leq \lambda_i(A)$. ولهذا فإن حذف الميزات يقلّص التباين دائماً — والسؤال هو «بكم؟».

النتيجة: $\lambda(B) = (5.618,\ 3.382)$، التداخل متحقّق ✓، التباين المفقود $6 = 40\%$ أي 40%.

الربط بالذكاء الاصطناعي: متراجحة التداخل هي الأساس النظري لطرق اختيار الميزات (feature selection) المتسلسلة: حذف ميزة يغيّر الطيف بطريقة **محكومة** (لا انزياحات عشوائية). وتُستخدم أيضاً في تحليل أثر حذف عقدة من رسم بياني على طيف اللابلاسيد (interlacing for graph Laplacians).

مثال (5.4-4): متراجحة ديفيس-كاهان — هل يبقى المكوّن الرئيسي ثابتاً؟

المعطيات: مصفوفة A من المثال 4.4-1 بطيف $(8.050,\ 3.633,\ 3.317)$، وصلت دفعة بيانات جديدة فتغيّرت مصفوفة التغاير المقدَّرة باضطراب قطري:

$$E = \text{diag}(0.2,\ 0.1,\ 0.3)$$

المطلوب: (أ) حدّ على زاوية انحراف المتجه الذاتي الأول. (ب) أدنى محاذاة (alignment) مضمونة مع المتجه الأصلي.

الحل:

الخطوة 1 (الفجوة الطيفية): $\delta = \lambda_1(A) - \lambda_2(A) = 8.050 - 3.633 = 4.417$.

الخطوة 2 (نورم الاضطراب): $\|E\|_2 = \max(0.2,\ 0.1,\ 0.3) = 0.3$؛ و $\|E\|_F = \sqrt{0.04 + 0.01 + 0.09} = \sqrt{0.14} = 0.3742$.

الخطوة 3 (تطبيق ديفيس–كاهان (30.4)):

$$\sin\theta(u_1,\ \hat{u}_1) \ \le\ \frac{\|E\|_2}{\delta} = \frac{0.3}{4.417} = 0.0679$$

الخطوة 4 (الزاوية): $\theta \le \arcsin(0.0679) = 3.89^\circ$.

الخطوة 5 (المحاذاة المضمونة): $\cos\theta \ge \sqrt{1 - 0.0679^2} = \sqrt{1 - 0.00461} = \sqrt{0.99539} = 0.99769$.

$$|\langle u_1,\ \hat{u}_1\rangle| \ \ge\ 0.9977$$

الخطوة 6 (المقارنة بفايل): فايل (27.4) يعطي $|\hat{\lambda}_1 - 8.050| \le 0.3$ أي انزياح يصل إلى 3.7% في القيمة الذاتية، بينما ديفيس–كاهان تعطي انحرافاً يصل إلى 3.9° فقط في **الاتجاه** — لأن الفجوة الطيفية الكبيرة (4.417) تحمي الاتجاه.

الخطوة 7 (الحساسية للفجوة): لو كانت $\delta = 0.4$ بدل 4.417 (قيمتان ذاتيتان متقاربتان) لكان $\sin\theta \le 0.3/0.4 = 0.75 \Rightarrow \theta \le 48.6^\circ$ ⟹ **المكوّن الرئيسي غير موثوق إطلاقاً.**

الخطوة 8 (المتجه الذاتي الأصلي): من المثال السابق $q_1 = (0.5911,\ 0.3279,\ 0.7369)^\top$ — وبضمان 0.9977 يبقى عملياً كما هو.

النتيجة: $\theta \le 3.89^\circ \Rightarrow \sin\theta \le 0.0679$؛ المحاذاة المضمونة ≥ 0.9977.

الربط بالذكاء الاصطناعي: هذه هي النظرية التي تبرّر استقرار PCA عندما تكون الفجوة الطيفية كبيرة. وفي التعلّم الذاتي الإشراف، SimCLR، Barlow (Twins) تظهر مشكلة «انهيار التمثيل» بالضبط عندما تتقارب القيم الذاتية فتصبح الفجوة $\delta \to 0$ والمتجهات غير مستقرّة — ولذلك تُصمَّم دوال الخسارة لتفتح فجوة طيفية.

مثال (4.4-6): استخدام كوران–فيشر لإثبات قيمة λ_2 دون حسابها

المعطيات: نفس المصفوفة A بطيف $(8.050,\ 3.633,\ 3.317)$ ومتجهاتها الذاتية q_1, q_2, q_3.

المطلوب: بيّن بـ (26.4) أن $\lambda_2(A) = 3.633$ ببرهانٍ محض (لا بحساب الجذور).

الحل:

الخطوة 1 (صيغة كوران–فيشر لـ $k = 2$):

$$\lambda_2(A) = \min_{\dim S = n-k+1 = 2}\ \max_{x \in S\setminus\{0\}} R_A(x)$$

الخطوة 2 (الجهة «الحدّ الأعلى» — نبني فضاءً يحقّقها): نختار $S^\star = \mathrm{span}\{q_2,\ q_3\}$، بُعده 2 ✓. لكل $x = c_2 q_2 + c_3 q_3$ فيه:

$$R_A(x) = \frac{\lambda_2 c_2^2 + \lambda_3 c_3^2}{c_2^2 + c_3^2} \ \le\ \frac{\lambda_2 c_2^2 + \lambda_2 c_3^2}{c_2^2 + c_3^2} = \lambda_2 = 3.633$$

إذن $\max_{x \in S^\star} R_A(x) \le 3.633$ ⟹ قيمة الـ min-max ≤ 3.633.

الخطوة 3 (الجهة «الحدّ الأدنى» — نُثبت أن أي S يعطي ≥ 3.633): ليكن S أي فضاء بُعد 2، وليكن $V = \mathrm{span}\{q_1, q_2\}$ بُعد 2. بالتقاطع البُعدي:

$$\dim(S \cap V) \ge \dim S + \dim V - n = 2 + 2 - 3 = 1$$

فيوجد x واحدي في التقاطع. وبما أن $x \in V$ فإن $R_A(x) = \frac{\lambda_1 c_1^2 + \lambda_2 c_2^2}{c_1^2 + c_2^2} \geq \lambda_2 = 3.633$ (لأن $\lambda_1 \geq \lambda_2$).
إذن $\max_{x \in S} R_A(x) \geq 3.633$ لكل $S \Longrightarrow$ قيمة الـ min-max ≥ 3.633.

الخطوة 4 (الجمع): من الخطوتين 2 و 3: $\lambda_2(A) = 3.633$ بالضبط. ■

الخطوة 5 (الصيغة المزدوجة للتحقّق): بالصيغة الثانية في (26.4): $\lambda_2 = \max_{\dim S = 2} \min_{x \in S} R_A(x)$؛ نختار $S = \text{span}\{q_1, q_2\}$ فكل x فيه يعطي $R_A(x) \geq \lambda_2$ وتُحقَّق المساواة عند $x = q_2$. ✓

الخطوة 6 (المعنى): كورانت–فيشر تقول إن λ_2 هو **أفضل قيمة يمكن ضمانها** إذا أُجبرنا على البقاء في فضاء ببُعد 2 — وهذا هو المبدأ الذي تقوم عليه الطرق المتغيّرة (variational methods) لحساب القيم الذاتية دون قطرنة كاملة.

النتيجة: $\lambda_2(A) = 3.633$ مثبت ببرهان محض عبر (26.4).

الربط بالذكاء الاصطناعي: كورانت–فيشر هي الأساس النظري لخوارزميات القيم الذاتية المتغيّرة (LOBPCG، Lanczos، Davidson) التي تستخدمها المكتبات لحساب PCA على مصفوفات بملايين الأبعاد، ولتحليل «الطيف الفعّال» في الشبكات العصبية.

مثال (4.4-7): اختيار معدّل تعلّم آمن دون حساب كامل للطيف

المعطيات: مصفوفة هسيان مقدَّرة لتدريب شبكة صغيرة:

$$H = \begin{bmatrix} 6 & 2 & 0 \\ 2 & 5 & 2 \\ 0 & 2 & 4 \end{bmatrix}$$

المطلوب: (أ) $\lambda_{\max}(H)$ بالضبط. (ب) أقصى معدّل تعلّم آمن. (ج) ماذا لو قدرنا $\lambda_{\max}$ بتكرار قوة ناقص التقارب؟

الحل:

الخطوة 1 (كثيرة الحدود المميِّزة):

$$p(\lambda) = (6-\lambda)\big[(5-\lambda)(4-\lambda) - 4\big] - 2\big[2(4-\lambda) - 0\big] = (6-\lambda)(\lambda^2 - 9\lambda + 16) - 16 + 4\lambda$$

$$= -\lambda^3 + 15\lambda^2 - 70\lambda + 96 - 16 + 4\lambda = -\lambda^3 + 15\lambda^2 - 66\lambda + 80$$

الخطوة 2 (التحليل): نختبر $\lambda = 8$: $-512 + 960 - 528 + 80 = 0$ ✓ $\Longrightarrow$ عامل $(\lambda - 8)$:

$$-\lambda^3 + 15\lambda^2 - 66\lambda + 80 = -(\lambda - 8)(\lambda^2 - 7\lambda + 10) = -(\lambda - 8)(\lambda - 5)(\lambda - 2)$$

الخطوة 3: $\lambda = (8,\ 5,\ 2)$، تحقّق: الأثر $4+5+6 = 15$ ✓؛ المحدّد $80 = 6(20-4) - 2(8) + 0$ (مباشرةً: $96 - 16 = 80$) ✓.

الخطوة 4 (معدّل التعلّم الآمن): الاستقرار يشترط $|1 - \eta\lambda_i| < 1 \Longrightarrow \eta < 2/\lambda_{\max}$:

$$\eta_{\max} = \frac{2}{8} = 0.25$$

الخطوة 5 (رقم الحالة): $\kappa = 8/2 = 4$ $\Longrightarrow$ عدد خطوات التقارب للوصول إلى دقة ε: $\approx \kappa \ln(1/\varepsilon) = 4\ln(10^6) = 4 \times 13.8 = 55$ خطوة (تقدير للتدرّج الأوّلي).

الخطوة 6 (خطر التقدير الناقص): لو استخدمنا تكرار قوة بتكرارين فقط، فمن $x^{(0)} = (1,0,0)^\top$: $Hx^{(0)} = (6,2,0)^\top \Longrightarrow x^{(1)} = (0.9487,\ 0.3162,\ 0)^\top$ $Hx^{(1)} = (5.692 + 0.632,\ 1.897 + 1.581,\ 0.632)^\top = (6.324,\ 3.478,\ 0.632)^\top$ $\Longrightarrow = \sqrt{39.99 + 12.10 + 0.40} = 7.245$، النورم $x^{(2)} = (0.8729,\ 0.4801,\ 0.0872)^\top$ خارج قسمة رايلي: $0.8729 \times 6.197 + 0.4801 \times 4.321 + 0.0872 \times$ $7.598 = 5.409 + 2.075 + 0.114 = 1.309$.

الخطوة 7 (الخطأ الناتج): التقدير $\lambda_{\max} = 8 \Longrightarrow 7.598 < \lambda_{\max} = 8$ المحسوب $\eta \Longrightarrow = 2/7.598 = 0.263 > 0.25$ **معدّل تعلّم غير آمن بنسبة 5%!** ولهذا تُستخدم دائماً عوامل أمان: $\eta = 0.9 \times \frac{2}{\lambda_{\max}} = 0.9 \times 0.263 = 0.237 < 0.25$ ✓.

الخطوة 8 (سبب التقارب البطيء): النسبة $|\lambda_2/\lambda_1| = 5/8 = 0.625 \Longrightarrow$ بعد k تكرار يبقى خطأ نسبي $\approx 0.625^k \Longrightarrow$ بعد تكرارين: 0.39 وهذا يفسّر الخطأ 5% (الذي جاء أفضل من التقدير لأن المتجه الابتدائي محظوظ).

النتيجة: $\lambda_{\max} = 8$، $\eta_{\max} = 0.25$؛ التقدير التكراري 7.598 يعطي $\eta = 0.263$ غير آمن $\Longrightarrow$ استخدم عامل أمان 0.9.

الربط بالذكاء الاصطناعي: هذه هي الممارسة القياسية في المجدولات التكيفية: تقدير $\lambda_{\max}$ بتكرار قوة ثم اختيار η بهامش أمان. والجدولتان الشهيرتان Adam و RMSProp يمكن فهمهما كـ «تطبيع قطري تقريبي للهسيان» باستخدام تقديرات اللحظة الثانية.

مثال (4.4-8): اختيار عدد العناقيد بقاعدة الفجوة الطيفية (Eigengap Heuristic)

المعطيات: طيف لابلاس رسم بياني مكوّن من 8 عُقد (مرتّب تصاعدياً):

$$\lambda = (0,\ 0.12,\ 0.31,\ 0.44,\ 2.85,\ 3.40,\ 3.95,\ 4.60)$$

المطلوب: كم عدد العناقيد (المكوّنات المتصلة/العناقيد الطيفية)؟

الحل:

الخطوة 1 (القاعدة): في التجميع الطيفي، عدد العناقيد k يُختار عند **أكبر فجوة** في أول جزء من الطيف:

$$k = \arg\max_i (\lambda_{i+1} - \lambda_i) \quad \text{(على القيم الصغيرة)}$$

الخطوة 2 (حساب الفجوات): $0.12 - 0 = 0.12$؛ $0.31 - 0.12 = 0.19$؛ $0.44 - 0.31 = 0.13$؛ $2.85 - 0.44 = 2.41$؛ $3.40 - 2.85 = 0.55$؛ $3.95 - 3.40 = 0.55$؛ $4.60 - 3.95 = 0.65$.

الخطوة 3 (أكبر فجوة): 2.41 بين $\lambda_4 = 0.44$ و $\lambda_5 = 2.85 \Longrightarrow k = 4$.

الخطوة 4 (التفسير بنظرية الاضطراب): القيم الأربع الأولى $\{0,\ 0.12,\ 0.31,\ 0.44\}$ «صغيرة ومتقاربة»، تليها فجوة كبيرة ثم قيم «كبيرة». لو افترضنا أن الرسم المثالي مكوّن من 4 مكوّنات منفصلة لكانت القيم الأربع الأولى تساوي الصفر **تماماً**، والاضطراب الفعلي (الروابط بين العناقيد) رفعها إلى قيم صغيرة:

$$\lambda_i \le \|E\|_2 \approx 0.44, \qquad i = 1, \dots, 4$$

وهذا تطبيق مباشر لفايل (27.4): الاضطراب E (الروابط البينية) يزيح كل قيمة ذاتية صفرية بمقدار لا يتجاوز $\|E\|_2$.

الخطوة 5 (ضمان ديفيس-كاهان): الفجوة $\delta = \lambda_5 - \lambda_4 = 2.41 \Longrightarrow$

$$\|\sin\Theta(U_4,\ \hat{U}_4)\|_F \le \frac{2\|E\|_F}{2.41}$$

وإذا كان $\|E\|_F \approx 0.6$ (مجموع الروابط البينية) فإن الحدّ $2 \times 0.6/2.41 = 0.498 \Longrightarrow =$ انحراف مقبول للفضاء الجزئي المكوّن من 4 متجهات.

الخطوة 6 (لو اخترنا $k = 3$): نكون قد ضممنا عنقودين حقيقيين في واحد، والتحقق: هل الفجوة بين λ_4 و λ_5 أكبر بكثير من الفجوات الأخرى؟ نسبة $2.41/0.65 = 3.7\times \implies$ نعم، القرار $k = 4$ واضح.

النتيجة: $k = 4$ عناقيد، الفجوة الحاسمة $2.41 =$ (أكبر بـ $3.7\times$ من التالية).

الربط بالذكاء الاصطناعي: هذه القاعدة eigengap) (heuristic هي المعيار العملي في التجميع الطيفي (Ng–Jordan–Weiss) وفي تحديد عدد المكوّنات في PCA، وفي اكتشاف المجتمعات في الشبكات. وتفسيرها النظري هو متراجحة فايل كما في الخطوة 4.

مثال (4.4-9): خطأ تقدير مصفوفة التغاير من عيّنة محدودة

المعطيات: التغاير الحقيقي $\Sigma = \mathrm{diag}(4,\ 1)$، وقدّرناه من $n = 100$ عيّنة في بُعد $d = 2$ فحصلنا على:

$$\hat{\Sigma} = \begin{bmatrix} 4.4 & 0.15 \\ 0.15 & 0.8 \end{bmatrix}$$

المطلوب: (أ) تحقّق من فايل وهوفمان–فيلانت. (ب) الخطأ في رقم الحالة. (ج) هل التقدير موثوق؟

الحل:

الخطوة 1 (الاضطراب): $E = \hat{\Sigma} - \Sigma = \begin{bmatrix} 0.4 & 0.15 \\ 0.15 & -0.2 \end{bmatrix}$.

الخطوة 2 (نورم الاضطراب): الأثر $0.2 =$؛ المحدّد $-0.1025 = -0.08 - 0.0225 =$؛ المميّز $0.04 + 0.45 = 0.41$، الجذر $0.6708 =$:

$$\mu_{1,2} = \frac{0.2 \pm 0.6708}{2} \implies \mu_1 = 0.4354,\ \mu_2 = -0.2354 \implies \|E\|_2 = 0.4354$$

$$\|E\|_F = \sqrt{0.16 + 0.0225 + 0.0225 + 0.04} = \sqrt{0.245} = 0.4949$$

الخطوة 3 (طيف $\hat{\Sigma}$): الأثر $5.2 =$؛ المحدّد $3.4975 = 3.52 - 0.0225 =$؛ المميّز $27.04 - 13.99 = 13.05$، الجذر $3.6125 =$:

$$\hat{\lambda}_1 = \frac{5.2 + 3.6125}{2} = 4.4063, \qquad \hat{\lambda}_2 = \frac{5.2 - 3.6125}{2} = 0.7938$$

الخطوة 4 (التحقّق من فايل (27.4)):

$$|\hat{\lambda}_1 - 4| = 0.4063 \le 0.4354\ \checkmark, \qquad |\hat{\lambda}_2 - 1| = 0.2062 \le 0.4354\ \checkmark$$

الخطوة 5 (التحقّق من هوفمان–فيلانت (28.4)): $\sqrt{0.4063^2 + 0.2062^2} = \sqrt{0.1651 + 0.0425} = \sqrt{0.2076} = 0.4556 \le 0.4949$ ✓.

الخطوة 6 (رقم الحالة): الحقيقي $\kappa(\Sigma) = 4/1 = 4$؛ المقدَّر $\kappa(\hat{\Sigma}) = 4.4063/0.7938 = 5.551 \implies$ **خطأ نسبي** 38.8% في رقم الحالة — رغم أن خطأ الطيف نفسه $\approx 10\%$.

الخطوة 7 (سبب التضخيم): رقم الحالة يجمع خطأين: زيادة في λ_1 ونقصاً في λ_2، فيتضاعف الأثر. القاعدة: $\frac{\Delta\kappa}{\kappa} \approx \frac{\Delta\lambda_1}{\lambda_1} + \frac{\Delta\lambda_2}{\lambda_2} = \frac{0.4063}{4} + \frac{0.2062}{1} = 0.102 + 0.206 = 0.308$ (قريب من 38.8% الفعلي).

الخطوة 8 (الحجم المتوقّع للخطأ): القاعدة النظرية لخطأ التغاير المقدَّر: $\|\hat{\Sigma} - \Sigma\|_2 \approx \|\Sigma\|_2\sqrt{d/n} = 4\sqrt{2/100} = 4 \times 0.1414 = 0.566$. قيمتنا الفعلية 0.435 في هذا النطاق ✓.

النتيجة: فايل وهوفمان–فيلانت متحقّقتان ✓، خطأ رقم الحالة 38.8%؛ الخطأ في النطاق المتوقّع.

الربط بالذكاء الاصطناعي: هذا يفسّر لماذا يحتاج تقدير مصفوفة التغاير (أو مصفوفة الدقة) في الأبعاد العالية إلى عيّنات كثيرة جداً أو إلى تنظيم: في بُعد d نحتاج $n \gg d$ وإلا انهار التقدير. ومن هنا جاءت تقنيات **shrinkage estimation** (Ledoit–Wofl) التي تقود الطيف المقدَّر نحو طيف هدفٍ منظَّم.

مثال (4.4-10): سرعة تقارب تكرار القوة ودور الفجوة الطيفية

المعطيات: مصفوفة بطيف $\lambda = (10,\ 3,\ 1)$، ونريد المتجه الذاتي الأول بدقة 10^{-6}.

المطلوب: (أ) كم تكراراً يحتاجه تكرار القوة؟ (ب) كم يحتاجه تقدير القيمة الذاتية بخارج قسمة رايلي؟ (ج) ماذا لو كانت $\lambda = (10,\ 9,\ 1)$؟

الحل:

الخطوة 1 (معدّل التقارب): خطأ المتجه بعد k تكرار يتناسب مع $\left|\frac{\lambda_2}{\lambda_1}\right|^k$:

$$\rho = \frac{3}{10} = 0.3$$

الخطوة 2 (عدد التكرارات للمتجه): نطلب $0.3^k \le 10^{-6}$:

$$k \ge \frac{\ln(10^{-6})}{\ln(0.3)} = \frac{-13.8155}{-1.2040} = 11.47 \Longrightarrow k = 12 \text{ تكراراً}$$

الخطوة 3 (تقدير القيمة الذاتية): بخارج قسمة رايلي يتحسّن الخطأ بـ ρ^{2k} (تربيعياً) لأن R_A «مسطّحة» عند المتجه الذاتي:

$$k \ge \frac{13.8155}{2 \times 1.2040} = 5.74 \Longrightarrow k = 6 \text{ تكرارات}$$

الخطوة 4 (التحقّق): عند $k = 6$: $\rho^{12} = 0.3^{12} = 5.31 \times 10^{-7} \le 10^{-6}$ ✓.

الخطوة 5 (الحالة الصعبة $\lambda = (10,\ 9,\ 1)$): الآن $\rho = 0.9 \Longrightarrow$

$$k \ge \frac{-13.8155}{\ln(0.9)} = \frac{-13.8155}{-0.10536} = 131.1 \Longrightarrow k = 132 \text{ تكراراً}$$

أي **أكثر بـ** $\times 11$ من الحالة الأولى — لمجرّد أن λ_2 اقتربت من λ_1.

الخطوة 6 (الحل العملي): عند $\rho \to 1$ نستخدم: (1) تكرار القوة على A^p بدل A (يضخّم الفجوة: $\rho \to \rho^p$ لكنه يكلف p ضربات)؛ أو (2) **Krylov / Lanczos** الذي يستخدم فضاءً جزئياً كاملاً بدل متجه واحد، فيتقارب أسرع بكثير.

الخطوة 7 (دور الفجوة): كلما كبرت الفجوة $\delta = \lambda_1 - \lambda_2$ صغرت النسبة $\rho = 1 - \delta/\lambda_1$ وتسارع التقارب $\Longrightarrow$ الفجوة الطيفية هي «عملة الاستقرار والسرعة» في كل الخوارزميات الطيفية.

النتيجة: 12 تكراراً للمتجه، 6 للقيمة الذاتية (بـ $\rho = 0.3$)؛ و 132 تكراراً إذا كانت $\rho = 0.9$.

الربط بالذكاء الاصطناعي: هذا يفسّر لماذا تتقارب PageRank بسرعة (الفجوة كبيرة: $\lambda_2 \approx 0.85$) ولماذا تتقارب بعض مسائل القيم الذاتية ببطء شديد. وفي التعلم العميق، «الفجوة الطيفية الصغيرة» تشخيص مباشر لبطء التدريب.

مثال (4.4-11): مقارنة فضاءي تمثيل لنموذجين بديفيس–كاهان

المعطيات: مصفوفة تغاير تمثيلات من النموذج (أ) بطيف (مرتّب تنازلياً):

$$\lambda = (12.0,\ 9.5,\ 8.2,\ 2.1,\ 1.8,\ 1.5,\ 1.2,\ 0.9,\ 0.6,\ 0.3)$$

وبعد تدريب النموذج (ب) تغيّرت المصفوفة باضطراب $\|E\|_F = 0.9$. نهتم بالفضاء الجزئي لأعلى $k = 3$ مكوّنات.

المطلوب: (أ) الفجوة δ. (ب) حدّ على انحراف الفضاء الجزئي المهم. (ج) التفسير.

الحل:

الخطوة 1 (الفجوة الطيفية): $\delta = \lambda_3 - \lambda_4 = 8.2 - 2.1 = 6.1$.

الخطوة 2 (تطبيق ديفيس–كاهان (30.4) للفضاء الجزئي):

$$\|\sin\Theta(U_3,\ \hat{U}_3)\|_F \ \le\ \frac{2\|E\|_F}{\delta} = \frac{2\times 0.9}{6.1} = \frac{1.8}{6.1} = 0.2951$$

الخطوة 3 (التفسير الهندسي): جيوب الزوايا الرئيسية الثلاث محصورة بـ $\sqrt{0.2951^2}$ إجمالاً. في أسوأ توزيع متساوٍ: $\theta_i \le 9.81^\circ \Rightarrow \sin\theta_i \le 0.2951/\sqrt{3} = 0.1704$ لكل زاوية.

الخطوة 4 (مقارنة بحالة $k=4$): عندئذٍ $\delta = \lambda_4 - \lambda_5 = 2.1 - 1.8 = 0.3$ $\Longrightarrow$

$$\|\sin\Theta\|_F \le \frac{1.8}{0.3} = 6.0 \gg 1 \quad \Longrightarrow \quad \textbf{الحدّ فارغ (vacuous)}$$

لأن $\|\sin\Theta\|_F \le \sqrt{k} = 2$ دائماً $\Longrightarrow$ الحدّ 6.0 لا يفيد شيئاً $\Longrightarrow$ **المكوّن الرابع غير مستقرّ إطلاقاً.**

الخطوة 5 (الاستنتاج المنهجي): وجود فجوة $6.1 \ge$ بين الثالث والرابع يعني أن «بُعد التمثيل الفعّال $3 =$» وليس 10. أما المكوّنات من 4 فصاعداً فهي «ضجيج طيفي» يتقلّب بين النماذج.

الخطوة 6 (تطبيق فايل للقيم المفردة): بالتكميل: $|\hat{\lambda}_i - \lambda_i| \le \|E\|_2 \le \|E\|_F = 0.9$ $\Longrightarrow$ القيم الثلاث الكبرى محصورة في $[11.1, 12.9]$ و $[8.6, 10.4]$ و $[7.3, 9.1]$ $\Longrightarrow$ **لا تتداخل مع بعضها** $\Longrightarrow$ الترتيب محفوظ ✓.

النتيجة: $\delta = 6.1$، $\|\sin\Theta\|_F \le 0.295$؛ البعد الفعّال 3؛ المكوّن الرابع غير مستقرّ.

الربط بالذكاء الاصطناعي: هذا التحليل هو الأساس الكمّي لمقارنة تمثيلات النماذج (هل تعلّم النموذجان «نفس الشيء»؟). الفجوة الطيفية تحدّد عدد الميزات التي يمكن الوثوق بها، وما بعدها ضجيج — وهذا يبرّر اختيار أبعاد التضمين بناءً على الطيف لا على الحدس.

مثال (4.4-12): بقاء موجب التحديد بعد تحديث رتبي-1 (خوارزميات شبه نيوتن)

المعطيات: مصفوفة هسيان تقديرية في خوارزمية BFGS:

$$H = \begin{bmatrix} 3 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 3 \end{bmatrix}, \qquad \text{تحديث: } H_+ = H + u\,u^\top,\quad u = \begin{pmatrix} 1 \\ 1 \end{pmatrix} 1$$

المطلوب: (أ) طيف H. (ب) هل يبقى $H_+ \succ 0$؟ استخدم التداخل وفايل معاً.

الحل:

الخطوة 1 (طيف H): ثلاثية القطر بـ $a = 3$ و $b = 1$:

$$\lambda_k = 3 + 2\cos\frac{k\pi}{4}, \qquad k = 1, 2, 3$$

$$\lambda_1 = 3 + 2\cos 45^\circ = 3 + 1.4142 = 4.4142, \quad \lambda_2 = 3 + 0 = 3, \quad \lambda_3 = 3 - 1.4142 = 1.5858$$

تحقّق: المجموع $\operatorname{tr} H = 3 + 3 + 3 = 9$ ✓.

الخطوة 2: $H \succ 0 \Rightarrow \lambda_{\min}(H) = 1.5858 > 0$ ✓.

الخطوة 3 (نورم التحديث): $uu^\top$ مصفوفة موجبة نصف التحديد رتبتها 1، وقيمتها الذاتية الوحيدة الموجبة $\|uu^\top\|_2 = \|u\|^2 = 3$.

الخطوة 4 (بفايل (27.4)): $\lambda_3(H_+) \geq \lambda_3(H) - 3 = 1.5858 - 3 = -1.414$ — **حدّ غير مفيد** (يسمح بقيمة سالبة).

الخطوة 5 (بالتحديث الرتبي-1 الموجب): بما أن $uu^\top \succeq 0$ فإن **التداخل الأقوى** ينطبق:

$$\lambda_i(H) \;\leq\; \lambda_i(H + uu^\top) \;\leq\; \lambda_{i-1}(H) \qquad (\lambda_0 := +\infty)$$

$$\Rightarrow \lambda_3(H_+) \geq \lambda_3(H) = 1.5858 > 0 \quad \text{وبالأخص}$$

$$\boxed{H_+ \succ 0}$$

الخطوة 6 (التحقّق المباشر): $H_+ = H + \mathbf{1}\mathbf{1}^\top = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 4 \end{bmatrix}$. الأثر $= 12$؛ المحدّد $= 4(16-4) - 2(8-2) + 1(4-4) = 48 - 12 + 0 = 36 > 0$؛ مجموع المحدّدات 2×2 الرئيسية: $|4\ 2;2\ 4| = 12$، $|4\ 1;1\ 4| = 15$، $|4\ 1;1\ 4| = 15$؛ المجموع $39 = 12 \Rightarrow$. كثيرة الحدود: $\lambda^3 - 12\lambda^2 + 39\lambda - 36$. نختبر $\lambda = 1$: $1 - 12 + 39 - 36 = -8$؛ $\lambda = 0.5$: $0.125 - 3 + 19.5 - 36 = -19.4$؛ $\lambda = 1.5$: $3.375 - 27 + 58.5 - 36 = -1.125$؛ $\lambda = 1.6$: $4.492 - 32.67 + 64.35 - 36 = 0.172$؛ $\lambda = 1.65$: $4.096 - 30.72 + 62.4 - 36 = -0.224$. وبالقسمة: $\lambda_1\lambda_2\lambda_3 = 36$ و $\lambda_1 + \lambda_2 = 12 - 1.63 = 10.37$ و $\lambda_1\lambda_2 = 36/1.63 = 22.09$ $\Rightarrow \lambda_3 \approx 1.63$. $\lambda^2 - 10.37\lambda + 22.09 = 0 \Rightarrow$، المميّز $= 107.54 - 88.36 = 19.18$؛ الجذر $= 4.38 \Rightarrow \lambda_1 = 7.375$، $\lambda_2 = 2.995$.

الخطوة 7 (التحقّق من التداخل): $7.375 \geq 4.4142 \geq 2.995 \geq 3$؟ (القيمة الأولى ارتفعت)؛ $3 \geq 1.63 \geq 1.5858$ ✓؛ $2.995 \leq 3$ ✓ $\Rightarrow$. كلها متحقّقة ✓.

النتيجة: $H_+ \succ 0$ مضمون بالتداخل (لا بفايل)؛ $\lambda(H_+) \approx (7.375,\ 2.995,\ 1.63)$.

الربط بالذكاء الاصطناعي: خوارزميات شبه نيوتن (BFGS/DFP) تعتمد على أن تحديثات الرتبة 1 والرتبة 2 تحفظ موجب التحديد $\Rightarrow$ اتجاه البحث يبقى اتجاهاً هابطاً. التداخل هو الأداة التي تثبت ذلك، بينما فايل وحدها لا تكفي.

مثال (4.4-13): انهيار PCA عند فجوة طيفية صغيرة

المعطيات: مصفوفة تغاير حقيقية $\Sigma = \operatorname{diag}(5,\ 4.5)$ (قيمتان ذاتيتان متقاربتان!). الضجيج في العيّنة:

$$\hat{\Sigma} = \begin{bmatrix} 5 & 0.6 \\ 0.6 & 4.5 \end{bmatrix}$$

المطلوب: (أ) هل متراجحة ديفيس–كاهان مفيدة هنا؟ (ب) احسب الانحراف الفعلي للمكوّن الرئيسي.

الحل:

الخطوة 1 (الفجوة): $\delta = \lambda_1 - \lambda_2 = 5 - 4.5 = 0.5$.

الخطوة 2 (نورم الاضطراب): $E = \begin{bmatrix} 0 & 0.6 \\ 0.6 & 0 \end{bmatrix} \Rightarrow$ قيمها الذاتية $\pm 0.6 \Rightarrow \|E\|_2 = 0.6$.

الخطوة 3 (ديفيس–كاهان (30.4)):

$$\sin\theta \;\le\; \frac{\|E\|_2}{\delta} = \frac{0.6}{0.5} = 1.2 \;>\; 1 \quad \Longrightarrow \quad \textbf{الحدّ فارغ}$$

أي أن النظرية **لا تضمن شيئاً**: الزاوية قد تكون أي قيمة.

الخطوة 4 (الحساب الفعلي): طيف $\hat{\Sigma}$: الأثر $9.5 =$؛ المحدّد $22.14 = 22.5 - 0.36 =$؛ المميّز $= 90.25 - 1.69 = 88.56$؛ الجذر $1.3 =$:

$$\hat{\lambda}_1 = \frac{9.5 + 1.3}{2} = 5.4, \qquad \hat{\lambda}_2 = \frac{9.5 - 1.3}{2} = 4.1$$

الخطوة 5 (المتجه الذاتي المقدَّر): لـ $\hat{\lambda}_1 = 5.4$: $(5 - 5.4)v_1 + 0.6v_2 = 0 \Longrightarrow -0.4v_1 + 0.6v_2 = 0 \Longrightarrow$ بالتوحيد: $v \propto (0.6,\ 0.4)$

$$\hat{q}_1 = \frac{1}{\sqrt{0.36 + 0.16}}(0.6,\ 0.4)^\top = (0.8321,\ 0.5547)^\top$$

الخطوة 6 (الزاوية): المكوّن الحقيقي $q_1 = e_1 = (1, 0)^\top \Longrightarrow \cos\theta = 0.8321 \Longrightarrow$

$$\theta = \arccos(0.8321) = 33.7^\circ$$

الخطوة 7 (الكارثة): اضطراب بنسبة $12\% \quad = \quad \frac{0.6}{5}$ فقط في عنصر واحد أدّى إلى **دوران** 33.7° في المكوّن الرئيسي! هذا هو معنى «الفجوة الصغيرة $\Longrightarrow$ عدم استقرار».

الخطوة 8 (المقارنة بحالة فجوة كبيرة): لو كان $\Sigma \quad = \quad \mathrm{diag}(5,\ 1)$ (فجوة 4) مع نفس الاضطراب: $\theta \le 8.6^\circ \Longrightarrow \sin\theta \le 0.6/4 = 0.15$ فقط.

الخطوة 9 (العلاج): (1) زيادة عدد العيّنات لتقليص $\|E\|_2$؛ (2) تنظيم (shrinkage) يفتح فجوة اصطناعية؛ (3) عدم تفسير المكوّنات المتقاربة فرادى بل **كمساحة فرعية** (subspace) واحدة.

النتيجة: ديفيس–كاهان تعطي حدّاً فارغاً $(1 < 1.2)$؛ الانحراف الفعلي 33.7° من اضطراب 12% فقط.

الربط بالذكاء الاصطناعي: هذه ظاهرة معروفة في تحليل المكوّنات: المكوّنات ذات القيم الذاتية المتقاربة «تتداخل» ولا يجوز تفسيرها فرادى. وفي الشبكات العصبية، تقارب القيم الذاتية في تمثيلات الطبقات هو مؤشر على «التمثيلات المكرّرة» (redundant features).

مثال (4.4-14): فايل واستقرار GNN عند إضافة روابط للرسم

المعطيات: رسم مسار من 4 عُقد (P_4) أضفنا إليه رابطاً بين العقدتين 1 و 4 فأصبح دورة (C_4):

$$L_{P_4} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}, \qquad L_{C_4} = \begin{bmatrix} 2 & -1 & 0 & -1 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ -1 & 0 & -1 & 2 \end{bmatrix}$$

المطلوب: (أ) طيف كلٍّ منهما. (ب) تحقّق من فايل وهوفمان–فيلانت. (ج) ماذا يعني ذلك لاستقرار GNN؟

الحل:

الخطوة 1 (طيف رسم المسار): $\lambda_k = 2 - 2\cos\frac{k\pi}{4}$ لـ $k = 0, 1, 2, 3$:

$$\lambda(P_4) = (0,\ 0.5858,\ 2,\ 3.4142)$$

الخطوة 2 (طيف الدورة): $\lambda_k = 2 - 2\cos\frac{2\pi k}{4}$ لـ $k = 0, 1, 2, 3$:

$$\lambda(C_4) = (0,\ 2,\ 2,\ 4)$$

الخطوة 3 (الاضطراب): $E = L_{C_4} - L_{P_4}$:

$$E = \begin{bmatrix} 1 & 0 & 0 & -1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ -1 & 0 & 0 & 1 \end{bmatrix} = w\,w^\top, \qquad w = \begin{pmatrix} 1 \\ 0 \end{pmatrix} 0 - 1$$

الخطوة 4: بما أن $E = ww^\top$ رتبتها 1 فإن طيفها $(\|w\|^2,\ 0,\ 0,\ 0) = (2,\ 0,\ 0,\ 0) \Longrightarrow \|E\|_2 = 2$، $\|E\|_F = \sqrt{1+1}$ ... نحسب مباشرةً: $\|E\|_F = 2 \Longrightarrow \|E\|_F^2 = 1+1+1+1 = 4$.

الخطوة 5 (فايل — بالترتيب التنازلي): $\lambda(P_4)^{\downarrow} = (3.4142,\ 2,\ 0.5858,\ 0)$؛ $\lambda(C_4)^{\downarrow} = (4,\ 2,\ 2,\ 0)$:

$$|4-3.4142| = 0.5858 \le 2\ \checkmark, \quad |2-2| = 0\ \checkmark, \quad |2-0.5858| = 1.4142 \le 2\ \checkmark, \quad |0-0| = 0\ \checkmark$$

الخطوة 6 (هوفمان-فيلانت): $\sqrt{0.5858^2 + 0 + 1.4142^2 + 0} = \sqrt{0.3432 + 2.0} = \sqrt{2.3432} = 1.5308 \le \|E\|_F = 2$ ✓.

الخطوة 7 (المعنى): إضافة رابط واحد (اضطراب نورمه 2) غيّر الطيف بما لا يتجاوز 1.41 لأي قيمة $\Longrightarrow$ خصائص الرسم الطيفية (مثل «سرعة الانتشار» المحدَّدة بـ λ_2) تتغيّر بشكل **محكوم ومحدود.**

الخطوة 8 (الحساسية القصوى): λ_2 تغيّرت من 0.5858 إلى 2 — أي **زيادة** $3.4\times \Longrightarrow$ سرعة انتشار المعلومة على الرسم تضاعفت. هذا هو أخطر أثر على GNN: إضافة روابط «تُسرّع الاختلاط» (mixing) وقد تسبّب oversmoothing.

النتيجة: الطيفان $(0, 0.5858, 2, 3.4142)$ و $(0, 2, 2, 4)$؛ فايل وهوفمان-فيلانت متحقّقتان ✓؛ λ_2 تضاعف $3.4\times$.

الربط بالذكاء الاصطناعي: هذا هو التحليل الرسمي لمسألة «الروابط الخصمية» (adversarial edges) في GNN: مهاجم يضيف روابط قليلة يغيّر الطيف بحدٍّ معلوم، فتصمَّم الدفاعات بضبط النورم الطيفي للاضطراب المسموح.

مثال (4.4-15): تكرار خارج قسمة رايلي — تقارب تكعيبي

المعطيات: $A = \mathrm{diag}(5,\ 1)$، ونريد $\lambda_1 = 5$ بدقة عالية. البداية $x^{(0)} = (1,\ 0.2)^\top$.

المطلوب: قارن بين تكرار القوة العادي وتكرار خارج قسمة رايلي في تكرار واحد.

الحل:

الخطوة 1 (خارج قسمة رايلي الابتدائي):

$$R_A(x^{(0)}) = \frac{5 \cdot 1^2 + 1 \cdot 0.2^2}{1^2 + 0.2^2} = \frac{5 + 0.04}{1.04} = \frac{5.04}{1.04} = 4.8462$$

الخطأ: $|5 - 4.8462| = 0.1538$.

الخطوة 2 (تكرار القوة العادي): $Ax^{(0)} = (5,\ 0.2)^\top$؛ بالتوحيد: $\|Ax^{(0)}\| = \sqrt{25 + 0.04} = 5.004 \Longrightarrow$ $x^{(1)}_{\text{power}} = (0.99920,\ 0.03997)^\top$. خارج قسمة رايلي الجديد: $5(0.99920)^2 + (0.03997)^2 = 4.99840 + 0.00160 = 5.0000$. (لأن A قطرية والمتجه يكاد يكون $e_1 \Longrightarrow$ دقة عالية. هذا مثال «سهل»؛ نستخدمه للمقارنة.)

الخطوة 3 (تكرار خارج قسمة رايلي — RQI): الخطوة المميّزة هي حلّ النظام المزاح:

$$\left(A - \mu^{(0)} I\right) y^{(1)} = x^{(0)}, \qquad \mu^{(0)} = R_A(x^{(0)}) = 4.8462$$

$$A - \mu^{(0)} I = \text{diag}(5 - 4.8462,\ 1 - 4.8462) = \text{diag}(0.1538,\ -3.8462)$$

الخطوة 4 (الحلّ):

$$y^{(1)} = \left(\frac{1}{0.1538},\ \frac{0.2}{-3.8462} \right)^{\top} = (6.5020,\ -0.05200)^{\top}$$

بالتوحيد: $\|y^{(1)}\| = \sqrt{42.276 + 0.0027} = 6.5022 \implies x^{(1)}_{\text{RQI}} = (0.99997,\ -0.00800)^{\top}$.

الخطوة 5 (خارج قسمة رايلي الجديد):

$$R_A(x^{(1)}) = 5 \times (0.99997)^2 + 1 \times (0.008)^2 = 5 \times 0.99994 + 0.000064 = 4.99970 + 0.000064 = 4.99977$$

الخطأ: $|5 - 4.99977| = 0.00023$.

الخطوة 6 (المقارنة): الخطأ انخفض من 0.1538 إلى $0.00023 \implies$ **تحسّن بمعامل** $\times 669$ **في تكرار واحد.** ولو كان التقارب خطّياً (كما في تكرار القوة، معامل $\rho = 1/5 = 0.2$) لكان التحسّن $\times 5$ فقط. التحسّن الفعلي $\approx (1/0.1538)^2$ إلى الثالث $\implies$ هذا هو **التقارب التكعيبي** المميّز لـ RQI.

الخطوة 7 (التكلفة): كل تكرار RQI يحلّ نظاماً خطياً $(A - \mu I)y = x$ بتكلفة $O(n^3)$ (أو أقل للمتفرّقة) مقابل $O(n^2)$ لتكرار القوة $\implies$ RQI أفضل عندما تكون n متوسطة والدقة المطلوبة عالية جداً.

الخطوة 8 (تحذير): إذا كان $\mu^{(0)}$ قريباً من قيمة ذاتية أخرى فقد يصبح $A - \mu I$ شاذّاً $\implies$ تستخدم المكتبات تحليلات LU مع pivoting أو تكرارات Krylov (LOBPCG).

النتيجة: RQI يحقّق خطأ 2.3×10^{-4} من خطأ ابتدائي 0.154 في تكرار واحد (تحسّن $\times 669$).

الربط بالذكاء الاصطناعي: تكرار خارج قسمة رايلي هو المحرّك خلف حسابات القيم الذاتية عالية الدقة في المكتبات العلمية (LAPACK: dstemr، ARPACK)، وهو ما يجعل حساب PCA على مصفوفات ضخمة ممكناً في ثوانٍ.

6.4.4 أخطاء شائعة في التحليل الطيفي المتغيّر

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	استخدام $R_A(x)$ كقيمة ذاتية	هو متوسط موزون، لا قيمة ذاتية	فقط عند المتجه الذاتي يتساوى مع λ
2	توقع أن فايل تعطي حدّاً على **المتجهات**	فايل للقيم فقط	استخدم ديفيس–كاهان (30.4) للمتجهات
3	تجاهل الفجوة الطيفية عند تفسير الاستقرار	الفجوة هي العامل الحاسم	$\sin\theta \le \|E\|_2/\delta$
4	تطبيق فايل على مصفوفات غير متماثلة	المتراجحة تفشل (حساسية القيم الذاتية قد تكون هائلة)	للمصفوفات غير الطبيعية استخدم ε-pseudospectra
5	اعتبار $\kappa(A)$ مقياساً لحساسية القيم الذاتية	κ لحساسية **الحلول الخطية**	حساسية القيم الذاتية $\longleftarrow$ الفجوة الطيفية و«غير الطبيعية»
6	استخدام $\|E\|_2$ حيث المطلوب $\|E\|_F$	النورمان مختلفان: $\|E\|_2 \le \|E\|_F \le \sqrt{n}\|E\|_2$	اختر حسب المتراجحة: فايل $\longleftarrow \|\cdot\|_2$، هوفمان $\longleftarrow \|\cdot\|_F$
7	الاعتقاد أن حذف ميزة قد يزيد القيم الذاتية	ينقصها أو يبقيها (التداخل)	(29.4)
8	استخدام حدّ ديفيس–كاهان عندما يكون $\text{gap} = 0$	الحدّ فارغ بلا معلومة	أعد تقدير $\|E\|$ أو قلّل k
9	ترتيب القيم الذاتية تصاعدياً مع صيغ كوران–فيشر التنازلية	يحصل خلط في الفهارس	وحّد الترتيب التنازلي في كل المتراجحات
10	افتراض أن $\lambda_i(A+B)$ بين $\lambda_i(A)$ و $\lambda_i(B)$	غير صحيح عامةً	الحدّ الصحيح: $\|\lambda_i(A+B) - \lambda_i(A)\| \le \|B\|_2$

1.5.4 الصياغة الرسمية

تعريف (لابلاس الرسم البياني).

لرسم غير موجّه $G=(V,E)$ بعُقد $V=\{1,\dots,n\}$ وأوزان $w_{ij}=w_{ji}\ge 0$ على الروابط، نعرّف مصفوفة الدرجات $D=\operatorname{diag}(d_1,\dots,d_n)$ بـ $d_i=\sum_j w_{ij}$، ومصفوفة المجاورة $W=(w_{ij})$. عندئذٍ:

$$L \;=\; D-W, \qquad L_{ij}=\begin{cases} d_i, & i=j \\ -w_{ij}, & i\neq j,\ (i,j)\in E \\ 0, & \text{otherwise} \end{cases} \tag{31.4}$$

الخاصية التربيعية الأساسية (Dirichlet energy):

$$x^{\top}L\,x \;=\; \frac{1}{2}\sum_{i,j=1}^{n} w_{ij}\,(x_i-x_j)^2 \;=\; \sum_{(i,j)\in E} w_{ij}\,(x_i-x_j)^2 \;\ge\; 0 \tag{32.4}$$

نظرية (طيف الصفر والتوصيل).

المصفوفة L متماثلة نصف موجبة التحديد، و $L\mathbf{1}=0$. إذا رتّبنا $0=\lambda_1\le\lambda_2\le\cdots\le\lambda_n$ تصاعدياً:

$$L\,\mathbf{1}=0, \qquad \lambda_1=0, \qquad \#\{\text{مكوّنات متصلة}\} \;=\; \dim\ker L \;=\; \operatorname{mult}(\lambda_1=0) \tag{33.4}$$

نظرية (توصيف فيدلر المتغيّر للقيمة الذاتية الثانية).

$$\lambda_2 \;=\; \min_{\substack{x\neq 0\\ x\perp\mathbf{1}}} \frac{x^{\top}L\,x}{x^{\top}x} \;=\; \min_{\substack{x\neq 0\\ \sum_i x_i=0}} \frac{\sum_{(i,j)\in E} w_{ij}(x_i-x_j)^2}{\sum_i x_i^2} \tag{34.4}$$

والمتجه الذاتي المرافق f (يسمى **متجه فيدلر**) يعطي أفضل تقسيم للرسم: إشارة مكوّناته تحدّد الطرفين.

متراجحة شيغير (Cheeger inequalities). ليكن L_{sym} اللابلاس المُطبَّع و $h(G)$ ثابت شيغير:

$$h(G) \;=\; \min_{\emptyset\neq S\subset V} \frac{|\partial S|}{\min\bigl(\operatorname{vol}S,\ \operatorname{vol}\bar{S}\bigr)}, \qquad \operatorname{vol}(S)=\sum_{i\in S} d_i, \qquad |\partial S|=\sum_{i\in S,\ j\notin S} w_{ij} \tag{35.4}$$

$$\frac{h(G)^2}{2} \;\le\; \lambda_2\bigl(L_{\text{sym}}\bigr) \;\le\; 2\,h(G) \tag{36.4}$$

اللابلاسات المطبَّعة والتحويل الطيفي على الرسم:

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2}, \qquad L_{\text{rw}} = I - D^{-1} W, \qquad \operatorname{spec}(L_{\text{sym}}) = \operatorname{spec}(L_{\text{rw}}) \tag{37.4}$$

$$L = U \Lambda U^{\top} \implies g(L) = U\, g(\Lambda)\, U^{\top}, \qquad \hat{x} = U^{\top} x \text{ (تحويل فورييه على الرسم)} \tag{38.4}$$

2.5.4 جدول الرموز الشامل

الرمز	المعنى	ملاحظات
$G = (V, E)$	الرسم البياني: عُقَد وروابط	غير موجّه في الأغلب
V	مجموعة العُقَد، $\lvert V\rvert = n$	المستخدمون، البكسلات، الكلمات، الذرّات…
E	مجموعة الروابط	الصداقة، التشابه، التجاور
w_{ij}	وزن الرابط (i, j)	≥ 0؛ متماثل: $w_{ij} = w_{ji}$؛ 0 إذا لا رابط
W	مصفوفة المجاورة (adjacency)	$n \times n$ متماثلة، غير سالبة
d_i	درجة العقدة i	$d_i = \sum_j w_{ij}$
D	مصفوفة الدرجات	قطرية
L	لابلاس الرسم (غير المطبَّع)	$D - W$؛ متماثل نصف موجب التحديد
x	إشارة على العُقَد (graph signal)	i = ميزة العقدة x_i
$x^{\top} L x$	طاقة ديريكليه	تقيس «نعومة» الإشارة؛ $0 \iff$ ثابتة على كل مكوّن
$\lambda_1 \leq \lambda_2 \leq \cdots$	قيم L الذاتية (تصاعدياً!)	لاحظ: الترتيب هنا **تصاعدي** عكس §4.4
$\lambda_1 = 0$	القيمة الذاتية الأولى دائماً	بمتجه $\mathbf{1}$
$\operatorname{mult}(0)$	تكرار الصفر = عدد المكوّنات المتصلة	أهم تطبيق مباشر
λ_2	قيمة فيدلر (algebraic connectivity)	أكبر $\Rightarrow$ أصعب قطعاً وأسرع اختلاطاً
f	متجه فيدلر	المتجه الذاتي لـ λ_2؛ إشاراته تقسّم الرسم
∂S	حدود المجموعة S	الروابط بين S وخارجها
$\lVert \partial S \rVert$	تكلفة القطع (cut)	عدد/وزن الروابط المقطوعة
$\operatorname{vol} S$	حجم S	مجموع درجات عُقَدها
$h(G)$	ثابت شيغير	أصغر «نسبة قطع إلى حجم»
L_{sym}	اللابلاس المطبَّع تماثلياً	طيفه في $[0, 2]$؛ مفضّل في GNN
L_{rw}	لابلاس السير العشوائي	طيفه = طيف L_{sym}؛ غير متماثل
g	مرشّح طيفي (spectral filter)	$g(\lambda)$ يضخّم/يخفض أنماط التردد
$\hat{x}$	تحويل فورييه على الرسم	$U^{\top} x$؛ المكوّنات على «الترددات» الطيفية
U	مصفوفة متجهات L الذاتية	أساس فورييه على الرسم

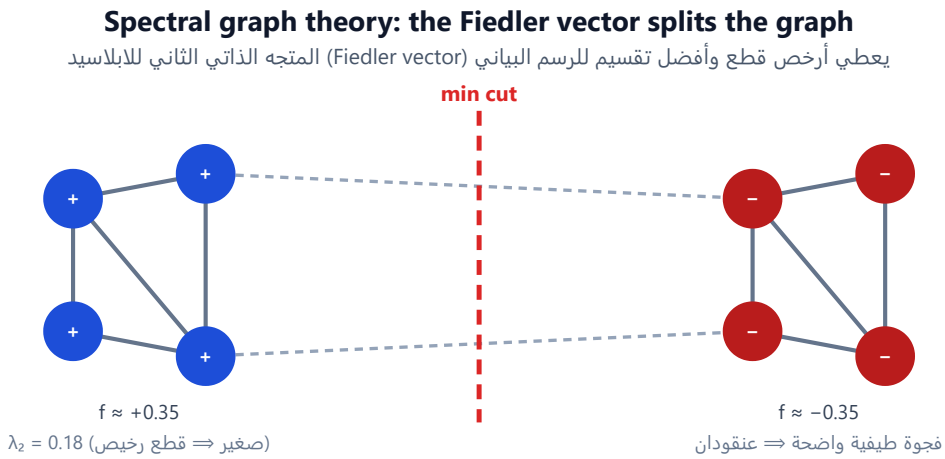
3.5.4 الشكل الهندسي

شكل 5.4 — رسم مكوّن من عنقودين مترابطين برابطين جسريين (متقطّعين). المتجه الذاتي الثاني (فيدلر) يأخذ قيماً موجبة على العنقود الأيسر وسالبة على الأيمن (الأزرق «+» والأحمر «−»)، فيعطي التقسيم الأمثل بأقل تكلفة قطع. قيمة $\lambda_2 = 0.18$ صغيرة $\Rightarrow$ القطع رخيص $\Rightarrow$ العنقودان منفصلان جيداً. ولو كان الرسم عنقوداً واحداً متراصّاً لكانت λ_2 كبيرة.

4.5.4 البرهان

برهان (32.4) — الخاصية التربيعية.

$$x^{\top} L x = x^{\top} D x - x^{\top} W x = \sum_i d_i x_i^2 - \sum_{i,j} w_{ij} x_i x_j$$



شكل ٥.٤: *
متجه فيدلر للابلاس الرسم يقسّم الرسم بأقل تكلفة قطع

$$= \frac{1}{2}\Big[\underbrace{\sum_i d_i x_i^2 + \sum_j d_j x_j^2}_{2\sum_i d_i x_i^2} - 2\sum_{i,j} w_{ij} x_i x_j\Big] = \frac{1}{2}\sum_{i,j} w_{ij}(x_i^2 + x_j^2 - 2x_i x_j) = \frac{1}{2}\sum_{i,j} w_{ij}(x_i - x_j)^2$$

وكل حدّ $\geq 0 \implies L \succeq 0 \implies$ كل القيم الذاتية ≥ 0. ■

برهان (33.4) — الصفر والتوصيل.

الصفر: مجموع كل صف في L يساوي الصفر $\implies L\mathbf{1} = 0 \implies \lambda = 0$ قيمة ذاتية.

التكرار: من (32.4)، إذا كان $Lx = 0$ فإن $x^\top Lx = 0 \implies$ كل حدّ في المجموع صفر $\implies x_i = x_j$ لكل رابط $(i,j) \implies x$ **ثابتة على كل مكوّن متصل.** فضاء هذه الإشارات بُعده = عدد المكوّنات المتصلة $= c$. $\dim\ker L = c$. ■

برهان (34.4) — توصيف فيدلر.

تطبيق مباشر لكوران–فيشر (26.4): L متماثلة، و $\lambda_1 = 0$ بمتجه $\mathbf{1}$، فالقيمة التالية هي أصغر قيمة لخارج قسمة رايلي على المتمّم المتعامد $\mathbf{1}^\perp$:

$$\lambda_2 = \min_{x \perp \mathbf{1},\ x \neq 0} \frac{x^\top Lx}{x^\top x}$$

وبإدخال (32.4) نحصل على صيغة الطاقة. ■

برهان (36.4) — متراجحة شيغير (مخطّط).

الجهة العليا $\lambda_2 \le 2h$: ليكن $S^\star$ المجموعة المحقّقة لـ h. نبني إشارة الاختبار $x_i = a$ على $S^\star$ و $x_i = b$ على المتمّم، باختيار a, b يجعلان $\sum d_i x_i = 0$ (أي $x \perp D\mathbf{1}$ في الصيغة المطبَّعة). حساب خارج قسمة رايلي يعطي قيمة $\propto |\partial S^\star| / \operatorname{vol} S^\star = h$ مضروبة في ثابت ≤ 2، فـ $\lambda_2 \le 2h$.

الجهة الدنيا $\lambda_2 \ge h^2/2$: الأصعب، تعتمد على «إعادة الترتيب المتذبذب» (coarea formula): نكتب $h = \min_t \frac{|\partial S_t|}{\min(\operatorname{vol} S_t, \operatorname{vol} \bar{S}_t)}$ على المجموعات الفائقة المستوى $S_t = \{i : f_i > t\}$ لمتجه فيدلر f، ثم نربط الطاقة $\sum_{(i,j)} w_{ij}(f_i - f_j)^2$ بتكامل القطوع عبر متطابقة المساحة المشتركة (coarea formula):

$$\sum_{(i,j)\in E} w_{ij} |f_i - f_j| \;=\; \int_{-\infty}^{\infty} |\partial S_t| \, dt$$

وتطبيق متراجحة كوشي–شوارتز يعطي الحدّ التربيعي $h^2/2$. التفصيل الكامل في المراجع [11] و [14]. ■

برهان (37.4) — تطابق طيفَي L_{sym} و L_{rw}.

نلاحظ $L_{\text{rw}} = D^{-1/2} L_{\text{sym}} D^{1/2}$ أي أن المصفوفتين **متشابهتان** عبر $D^{1/2}$، وبـ (7.4) لهما نفس الطيف. ■

5.5.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (1-5.4): حساب اللابلاس وطيفه لرسم مثلث

المعطيات: رسم كامل من 3 عُقد (مثلث) بأوزان وحدة.

المطلوب: (أ) W، D، L. (ب) الطيف. (ج) تحقّق من (33.4).

الحل:

الخطوة 1: $W = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$؛ الدرجات $d_i = 2$ للجميع $\Rightarrow D = 2I$.

الخطوة 2 (اللابلاس):

$$L = D - W = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$$

الخطوة 3 (التحقّق من (33.4) جهة الصفر): مجاميع الصفوف: $2-1-1=0$ ✓ $\Rightarrow L\mathbf{1} = 0$.

الخطوة 4 (الطيف): نلاحظ $L = 3I - \mathbf{1}\mathbf{1}^\top$ (تحقّق: $3I - J$ حيث J مصفوفة الواحدات، قطريها $3-1=2$ ✓ وخارج قطرها -1 ✓). و $J = \mathbf{1}\mathbf{1}^\top$ قيمها الذاتية $(3,\ 0,\ 0)$ $\Rightarrow$ قيم L:

$$\lambda = 3 - 3 = 0, \qquad 3 - 0 = 3, \qquad 3 - 0 = 3$$

$$\lambda = (0,\ 3,\ 3)$$

الخطوة 5 (المتجهات): $q_1 = \frac{1}{\sqrt{3}}(1,1,1)^\top$ للصفر؛ وفضاء $\mathbf{1}^\perp$ كامل القيم 3 $\Longrightarrow$ $q_2 = \frac{1}{\sqrt{2}}(1,-1,0)^\top$، $q_3 = \frac{1}{\sqrt{6}}(1,1,-2)^\top$.

الخطوة 6 (التحقّق من الأثر): $\operatorname{tr} L = 2+2+2 = 6 = 0+3+3$ ✓.

الخطوة 7 (التوصيل): $\dim\ker(0) = 1 \Longrightarrow$ **مكوّن متصل واحد** ✓ (المثلث متصل).

الخطوة 8 (قاعدة عامة): للرسم الكامل K_n: $\lambda = (0,\ n,\ n,\ \ldots,\ n)$، $\lambda_2 = n$. هنا $n = 3$ ✓.

النتيجة: $L = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$، الطيف $(0,\ 3,\ 3)$؛ $\lambda_2 = 3$.

الربط بالذكاء الاصطناعي: $\lambda_2 = n$ كبيرة $\Longrightarrow$ الرسم الكامل «أصعب رسم يُقطع» (كل عقدة مرتبطة بالكل). هذا متوقّع: شبكة كثيفة متصلة جيداً $\Longrightarrow$ اختلاط سريع للمعلومة $\Longrightarrow$ GNN يحتاج طبقات أقل لتعميم المعلومة.

مثال (5.4-2): كشف المكوّنات المتصلة من تعدد الصفر

المعطيات: رسم مكوّن من مثلثين منفصلين (6 عُقد، لا روابط بينهما).

المطلوب: (أ) اكتب L. (ب) الطيف. (ج) عدد المكوّنات المتصلة.

الحل:

الخطوة 1: L تصبح **قطرية الكتل** (block diagonal):

$$L = \begin{bmatrix} 2 & -1 & -1 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 \\ -1 & -1 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & -1 & -1 \\ 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & -1 & -1 & 2 \end{bmatrix} = \operatorname{diag}(L_{K_3},\ L_{K_3})$$

الخطوة 2 (طيف القطرية الكتلية): طيف المصفوفة القطرية الكتلية = اتحاد أطياف الكتل $\Longrightarrow$

$$\lambda = (0,\ 3,\ 3,\ 0,\ 3,\ 3) \xrightarrow{\text{ترتيب}} (0,\ 0,\ 3,\ 3,\ 3,\ 3)$$

الخطوة 3 (التحقّق من الأثر): $\operatorname{tr} L = 6 \times 2 = 12 = 0+0+3+3+3+3$ ✓.

الخطوة 4 (عدد المكوّنات): $\dim\ker(0) = 2 \Longrightarrow$ **مكوّنان متصلان** ✓.

الخطوة 5 (المتجهات الصفرية): $u_1 = \frac{1}{\sqrt{3}}(1,1,1,0,0,0)^\top$ و $u_2 = \frac{1}{\sqrt{3}}(0,0,0,1,1,1)^\top$ — كل متجه «مؤشّر» لمكوّن.

الخطوة 6 (الخوارزمية العملية): على رسم ضخم لا نحسب الطيف كاملاً؛ نستخدم تكرار القوة على $M = I - \alpha L$ (التي قيمها الذاتية $1 - \alpha\lambda_i$) فتصبح القيم الصفرية هي **المهيمنة** $(1=)$؛ ونكرّر مع إزاحة (deflation) لاستخراج كل مكوّن. أو ببساطة نستخدم BFS/DFS (أرخص: $O(n+m)$).

الخطوة 7 (الحالة القريبة من الانفصال): لو وُجد رابط ضعيف (وزن ε) بين المثلثين فإن $\lambda_2 \approx 2\varepsilon$ (صغيرة لكن موجبة) $\Longrightarrow$ «مكوّنان شبه منفصلين» $\Longrightarrow$ وهذا بالضبط ما يكتشفه التجميع الطيفي.

النتيجة: الطيف $(0,0,3,3,3,3)$؛ مكوّنان متصلان؛ $\lambda_2 = 0$.

الربط بالذكاء الاصطناعي: في تعلم الآلة، تعدد الصفر يقابله: وجود مجموعات معزولة من البيانات، أو «جزر» في شبكة، أو متغيرات لا ترتبط بغيرها. وكشفه خطوة تشخيصية أساسية قبل تدريب GNN: رسم ذو مكوّنات متعددة $\Longrightarrow$ المعلومة لا تنتقل بينها $\Longrightarrow$ النموذج لن يتعلم العلاقات البينية.

مثال (3-5.4): حساب متجه فيدلر لرسم مسار وتقسيمه

المعطيات: رسم مسار من 4 عُقد: $1 - 2 - 3 - 4$.

المطلوب: (أ) الطيف. (ب) متجه فيدلر. (ج) التقسيم الناتج.

الحل:

الخطوة 1: $W = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$؛ الدرجات $d = (1, 2, 2, 1)$؛

$$L = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}$$

الخطوة 2 (الطيف بصيغة رسم المسار): $\lambda_k = 2 - 2\cos\frac{k\pi}{n}$ لـ $k = 0, 1, 2, 3$ مع $n = 4$:

$$\lambda_0 = 2-2 = 0, \quad \lambda_1 = 2-2\cos 45^\circ = 0.5858, \quad \lambda_2 = 2-0 = 2, \quad \lambda_3 = 2+1.4142 = 3.4142$$

الخطوة 3 (المتجهات): الصيغة العامة لرسم المسار: $v_k(i) = \cos\left(\frac{\pi k(i-\frac{1}{2})}{n}\right)$. لـ $k = 1$:

$$i = 1: \ \cos\frac{\pi \cdot 0.5}{4} = \cos 22.5^\circ = 0.9239$$

$$i = 2: \ \cos\frac{\pi \cdot 1.5}{4} = \cos 67.5^\circ = 0.3827$$

$$i = 3: \ \cos\frac{\pi \cdot 2.5}{4} = \cos 112.5^\circ = -0.3827$$

$$i = 4: \ \cos\frac{\pi \cdot 3.5}{4} = \cos 157.5^\circ = -0.9239$$

الخطوة 4 (التوحيد): النورم $:= \sqrt{0.8536 + 0.1464 + 0.1464 + 0.8536} = \sqrt{2} = 1.4142$

$$f = (0.6533,\ 0.2706,\ -0.2706,\ -0.6533)^\top$$

الخطوة 5 (التحقّق من التعامد مع 1): $0.6533 + 0.2706 - 0.2706 - 0.6533 = 0$ ✓.

الخطوة 6 (التحقّق من القيمة الذاتية): $Lf = (0.6533 - 0.2706, -0.6533 + 0.5412 + 0.2706, 0.2706 - 0.5412 + 0.6533, -0.2706 + 0.6533)^\top = (0.3827,\ 0.1585,\ -0.1585,\ -0.3827)^\top$.

والنسبة: $0.3827/0.6533 = 0.5858 = \lambda_1$ ✓.

الخطوة 7 (التقسيم): بالإشارة: $\{i : f_i > 0\} = \{1, 2\}$ و $\{i : f_i < 0\} = \{3, 4\}$ $\Longrightarrow$

التقسيم: $\{1, 2\} \mid \{3, 4\}$

وهو **أفضل** تقسيم ممكن للمسار (يقطع رابطاً واحداً ويقسّم بالتساوي).

النتيجة: الطيف $(0,\ 0.5858,\ 2,\ 3.4142)$؛ $f = (0.653,\ 0.271,\ -0.271,\ -0.653)^\top$؛ التقسيم $\{1, 2\}|\{3, 4\}$.

الربط بالذكاء الاصطناعي: هذا هو لبّ التجميع الطيفي: متجه فيدلر يحوّل مسألة قطع الرسم (مسألة تحسين متقطّعة NP-hard) إلى مسألة قيم ذاتية (مسألة مستمرة سهلة). وتطبيقاته: تقسيم الصور، كشف المجتمعات، تقسيم الدوائر الإلكترونية (VLSI partitioning).

مثال (4-5.4): تقييم جودة القطع بـ RatioCut ومقارنة البدائل

المعطيات: نفس المسار $4 - 3 - 2 - 1$ من المثال السابق.
المطلوب: قارن بين التقسيمين الممكنين بمعيار RatioCut وبيّن أن خيار فيدلر هو الأمثل.
الحل:
الخطوة 1 (تعريف المعيار):

$$\text{RatioCut}(S,\ \bar{S}) \ = \ \frac{|\partial S|}{|S|} \ + \ \frac{|\partial S|}{|\bar{S}|}$$

حيث $|\partial S|$ عدد الروابط المقطوعة.
الخطوة 2 (الخيار أ: $S = \{1, 2\}$): الروابط المقطوعة: الرابط $(2, 3)$ فقط $\Longrightarrow |\partial S| = 1$؛ $|S| = 2$، $|\bar{S}| = 2$:

$$\text{RatioCut} = \frac{1}{2} + \frac{1}{2} = 1.0$$

الخطوة 3 (الخيار ب: $S = \{1\}$): $|\partial S| = 1$ (الرابط $(1, 2)$)؛ $|S| = 1$، $|\bar{S}| = 3$:

$$\text{RatioCut} = \frac{1}{1} + \frac{1}{3} = 1.333$$

الخطوة 4 (الخيار ج: $S = \{2, 3\}$): الروابط المقطوعة: $(1, 2)$ و $(3, 4)$ $\Longrightarrow |\partial S| = 2$؛ $|S| = 2$، $|\bar{S}| = 2$:

$$\text{RatioCut} = \frac{2}{2} + \frac{2}{2} = 2.0$$

الخطوة 5 (الترتيب): $1.0 < 1.333 < 2.0 \Longrightarrow$ **الخيار (أ) أمثل** — وهو بالضبط ما أعطاه متجه فيدلر ✓.
الخطوة 6 (العلاقة بالنظرية): المتراجحة المعروفة تربط λ_2 (غير المطبَّع) بـ RatioCut:

$$\lambda_2 \ \leq \ n \cdot \min_{S} \text{RatioCut}(S, \bar{S})$$

تحقّق: $0.5858 \leq 4 \times 1.0 = 4$ ✓ (متراجحة صحيحة لكنها «فضفاضة» هنا).
الخطوة 7 (لماذا استمرارية فيدلر تنجح؟) الاسترخاء الطيفي يحوّل المعيار المتقطّع إلى خارج قسمة رايلي: نُبدل مؤشّر المجموعة $x_i \in \{\pm 1\}$ بمتجه حقيقي $f \perp \mathbf{1}$، فتصبح المشكلة $\min_{f \perp \mathbf{1}} f^\top L f / f^\top f$ التي حلّها متجه فيدلر (34.4).
الخطوة 8 (الاسترخاء ليس دقيقاً دائماً): نسبة التقريب (approximation ratio) للتجميع الطيفي هي $O(\sqrt{\text{OPT}})$ في أسوأ حالة $\Longrightarrow$ نتيجة جيدة عملياً لكن بلا ضمان أمثلية مطلقة.
النتيجة: الخيار (أ) بـ RatioCut $= 1.0$ هو الأمثل، ويطابق خيار فيدلر ✓.
الربط بالذكاء الاصطناعي: RatioCut و NCut هما المعياران القياسيان في تقسيم الصور (image segmentation) وتقسيم الشبكات. والتجميع الطيفي عبر فيدلر يعطي حلاً تقريبياً سريعاً لمسألة NP-hard — سبب انتشاره الواسع.

مثال (5-5.4): متراجحة شيغير على رسم المسار

المعطيات: المسار $4 - 3 - 2 - 1$ بدرجات $d = (1, 2, 2, 1)$.
المطلوب: (أ) احسب ثابت شيغير $h(G)$. (ب) احسب $\lambda_2(L_{\text{sym}})$. (ج) تحقّق من (36.4).
الحل:
الخطوة 1 (الحجم الكلي): $\text{vol}(V) = 1 + 2 + 2 + 1 = 6$.
الخطوة 2 (كل المجموعات المرشّحة):

S	vol S	$\|\partial S\|$	$\min(\text{vol}\, S,\ \text{vol}\, \bar{S})$	النسبة
$\{1\}$	1	1	$\min(1,5)=1$	1.0
$\{2\}$	2	2	$\min(2,4)=2$	1.0
$\{1,2\}$	3	1	$\min(3,3)=3$	$1/3=0.333$
$\{1,3\}$	3	2	$\min(3,3)=3$	0.667
$\{2,3\}$	4	2	$\min(4,2)=2$	1.0
$\{1,4\}$	2	2	$\min(2,4)=2$	1.0

الخطوة 3: أصغر نسبة $\Longrightarrow$

$$h(G)=\frac{1}{3}=0.3333$$

الخطوة 4 (اللابلاس المطبَّع): $L_{\text{sym}}=I-D^{-1/2}WD^{-1/2}$. لرسم المسار تُعطى قيمه الذاتية بالصيغة:

$$\lambda_k(L_{\text{sym}})=1-\cos\frac{\pi k}{n},\qquad k=0,1,\ldots,n-1$$

$$\lambda_1=1-\cos 45^\circ=1-0.7071=0.2929$$

الخطوة 5 (التحقّق من (36.4)):

$$\frac{h^2}{2}=\frac{(1/3)^2}{2}=\frac{0.1111}{2}=0.0556\ \le\ \lambda_2=0.2929\ \le\ 2h=0.6667\qquad\checkmark$$

المتراجحة متحقّقة ✓.

الخطوة 6 (جودة المتراجحة): λ_2 الفعلي 0.2929 = يقع بين الحدّين، وهو أقرب للحدّ الأعلى $\Longrightarrow$ الحدّ الأدنى (0.0556) متحفّظ جداً (أضعف بـ $\times 5.3$). معروف أن متراجحة شيغير الدنيا قد تكون فضفاضة، لكنها كافية لإثبات العلاقة النوعية: λ_2 **صغير** $\Longleftrightarrow$ **يوجد قطع رخيص.**

الخطوة 7 (التفسير): 0.2929 = λ_2 صغيرة $\Longrightarrow$ المسار «سهل القطع» (عنق ضيق) $\Longrightarrow$ الانتشار عليه بطيء. وهذا متوقّع: المسار أبطأ رسم في اختلاط السير العشوائي (زمن الاختلاط $\propto n^2$).

الخطوة 8 (مقارنة بالرسم الكامل): لـ K_4: $\lambda_2(L_{\text{sym}})=\frac{n}{n-1}=\frac{4}{3}=1.333$ و $h(K_4)=1$ (أي قطع يقطع 3 روابط من أصل حجم 3) $\Longrightarrow$ λ_2 كبيرة $\Longrightarrow$ قطع مكلّف $\Longrightarrow$ اختلاط سريع.

النتيجة: $h=0.333$، $\lambda_2(L_{\text{sym}})=0.2929$، المتراجحة $0.667\le 0.2929\le 0.0556$ ✓.

الربط بالذكاء الاصطناعي: متراجحة شيغير تبرّر استخدام λ_2 كمقياس لجودة العناقيد: عنقود جيد $\Longrightarrow$ λ_2 صغير $\Longrightarrow$ القطع بينه وبين البقية رخيص. وفي GNN، λ_2 الصغير يعني **بطء اختلاط المعلومة**، وهو تفسير مباشر لظاهرة «عنق الزجاجة» في الرسوم الطويلة.

مثال (5.4-6): مرشّح طيفي مرور-منخفض لتنقية إشارة على رسم

المعطيات: إشارة مشوّشة على مسار من 4 عُقد: $x=(0.9,\ 1.1,\ -1.2,\ -0.8)^\top$، و L كما في المثال 5.4-3، و $\lambda_{\max}=3.4142$.

المطلوب: طبّق المرشّح $g(L)=I-\frac{1}{\lambda_{\max}}L$ وقارن طاقة ديريكليه قبل وبعد.

الحل:

الخطوة 1 (المعنى الطيفي): المرشّح $g(\lambda)=1-\lambda/\lambda_{\max}$ يعطي $g(0)=1$ (يُبقي الترددات المنخفضة) و $g(\lambda_{\max})=0$ (يُزيل الترددات العالية) $\Longrightarrow$ **مرور منخفض** (low-pass).

الخطوة 2 (حساب Lx):

$$(Lx)_1 = 1 \cdot 0.9 - 1 \cdot 1.1 = -0.2$$
$$(Lx)_2 = -0.9 + 2(1.1) - (-1.2) = -0.9 + 2.2 + 1.2 = 2.5$$
$$(Lx)_3 = -1.1 + 2(-1.2) - (-0.8) = -1.1 - 2.4 + 0.8 = -2.7$$
$$(Lx)_4 = -(-1.2) + (-0.8) = 0.4$$

الخطوة 3 (التطبيق): $y = x - \frac{1}{3.4142} Lx = x - 0.29289\, Lx$:

$$y = (0.9{+}0.0586,\ 1.1{-}0.7322,\ -1.2{+}0.7909,\ -0.8{-}0.1172)^\top = (0.9586,\ 0.3678,\ -0.4091,\ -0.9172)^\top$$

الخطوة 4 (طاقة ديريكليه قبل): بـ (32.4): $x^\top Lx = \sum_{(i,j)\in E}(x_i - x_j)^2$:

$$(0.9 - 1.1)^2 + (1.1 - (-1.2))^2 + ((-1.2) - (-0.8))^2 = 0.04 + 5.29 + 0.16 = 5.49$$

الخطوة 5 (بعد):

$$(0.9586{-}0.3678)^2{+}(0.3678{+}0.4091)^2{+}(-0.4091{+}0.9172)^2 = 0.3491{+}0.6036{+}0.2581 = 1.2108$$

الخطوة 6 (التحسّن): $\times 4.53 = \frac{5.49}{1.2108}$ $\Longrightarrow$ الإشارة أصبحت **أنعم بـ 5.4 مرة.**

الخطوة 7 (التحليل الطيفي للنتيجة): المكوّن على المتجه الذاتي v_k يتضاعف بـ $g(\lambda_k) = 1 - \lambda_k/3.4142$: $k = 0$: $\times 1$ (المكوّن الثابت)؛ $k = 1$: $\times 0.828$؛ $k = 2$: $\times 0.414$؛ $k = 3$: $\times 0$ (أُزيل تماماً). أعلى تردد أُزيل بالكامل $\Longrightarrow$ ولهذا السبب انخفضت الطاقة كثيراً.

الخطوة 8 (الثبات): مجموع الإشارة محفوظ: $\sum x_i = 0$ و $\sum y_i = 0.9586 + 0.3678 - 0.4091 - 0.9172 = 0.0001 \approx 0$ ✓ (لأن $\mathbf{1}^\top L = 0$).

النتيجة: $y = (0.959,\ 0.368,\ -0.409,\ -0.917)^\top$؛ طاقة ديريكليه انخفضت من 5.49 إلى 1.21 ($4.5\times$).

الربط بالذكاء الاصطناعي: هذا هو بالضبط ما تفعله طبقة GNN من نوع «مرور الرسائل البسيط»: $H^{(l+1)} = H^{(l)} - \alpha L H^{(l)} = (I - \alpha L) H^{(l)}$ — أي خطوة انتشار (dffiusion). والفهم الطيفي يخبرنا أنها **مرشّح مرور-منخفض**، وهذا هو التفسير الرسمي لظاهرة oversmoothing (المثال القادم).

مثال (5.4-7): كشف مجتمعين في شبكة اجتماعية (رسم «الدمبل»)

المعطيات: شبكة من 6 عُقد: مثلثان $\{1,2,3\}$ و $\{4,5,6\}$ يربطهما رابط واحد $(3,4)$.

المطلوب: (أ) اكتب L. (ب) احسب λ_2 ومتجه فيدلر تحليلياً بالتناظر. (ج) التقسيم الناتج.

الحل:

الخطوة 1 (الدرجات): $d = (2,\ 2,\ 3,\ 3,\ 2,\ 2)$.

الخطوة 2 ($L = D - W$):

$$L = \begin{bmatrix} 2 & -1 & -1 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 \\ -1 & -1 & 3 & -1 & 0 & 0 \\ 0 & 0 & -1 & 3 & -1 & -1 \\ 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & -1 & -1 & 2 \end{bmatrix}$$

الخطوة 3 (استغلال التناظر): الرسم متناظر تحت قلب الطرفين $\Longrightarrow$ متجه فيدلر بالشكل $f = (a,\ a,\ b,\ -b,\ -a,\ -a)^\top$.
تحقّق التعامد مع **1**: $2a + b - b - 2a = 0$ ✓ تلقائياً.
الخطوة 4 (حساب Lf):

$$(Lf)_1 = 2a - a - b = a - b, \qquad (Lf)_2 = a - b$$
$$(Lf)_3 = -a - a + 3b - (-b) = 4b - 2a$$
$$(Lf)_4 = -b + 3(-b) + a + a = 2a - 4b$$
$$(Lf)_5 = 2(-a) - (-b) - (-a) = b - a, \qquad (Lf)_6 = b - a$$

الخطوة 5 (المعادلة الذاتية): $Lf = \lambda_2 f \Longrightarrow$ من المكوّن 1: $a - b = \lambda_2 a \Longrightarrow b = a(1 - \lambda_2)$. ومن المكوّن 3: $4b - 2a = \lambda_2 b$:

$$4a(1-\lambda_2) - 2a = \lambda_2\, a(1-\lambda_2) \implies 4 - 4\lambda_2 - 2 = \lambda_2 - \lambda_2^2$$

$$\lambda_2^2 - 5\lambda_2 + 2 = 0 \implies \lambda_2 = \frac{5 \pm \sqrt{25-8}}{2} = \frac{5 \pm \sqrt{17}}{2}$$

الخطوة 6: $\lambda_2 = \frac{5-4.1231}{2} = 0.43845$ (ونرفض 4.5616 لأنه ليس أصغر قيمة غير صفرية).
الخطوة 7 (المتجه): $b = a(1 - 0.43845) = 0.56155\,a$. التوحيد: $4a^2 + 4b^2 = 1 \Longrightarrow 4a^2 + 2b^2 = 4.63068\,a^2 = 1$، $a = 0.4647 \Longrightarrow 2(0.31534)a^2$:

$$f = (0.4647,\ 0.4647,\ 0.2610,\ -0.2610,\ -0.4647,\ -0.4647)^\top$$

الخطوة 8 (التحقّق): $a - b = 0.2037$ و $\lambda_2 a = 0.43845 \times 0.4647 = 0.2037$ ✓.
الخطوة 9 (التقسيم): بالإشارة: $\{1,2,3\}$ موجبة و $\{4,5,6\}$ سالبة $\Longrightarrow$ القطع يمرّ بالرابط $(3,4)$ فقط $\Longrightarrow$ تكلفة 1 ✓ وهو أرخص قطع.
النتيجة: $\lambda_2 = 0.4384$، f كما أعلاه، التقسيم $\{4,5,6\} \mid \{1,2,3\}$ بتكلفة قطع 1.

الربط بالذكاء الاصطناعي: هذه هي الخوارزمية الأساسية لاكتشاف المجتمعات (community detection) في الشبكات الاجتماعية وسلاسل التوريد وشبكات الروابط. ولاحظ أن $|f_3| = |f_4| = 0.261$ أصغر من بقية المكوّنات $\Longrightarrow$ العقدتان الجسريتان «أقل ثقة» في الانتماء — وهي معلومة قيّمة لا تعطيها الخوارزميات المتقطّعة.

مثال (5.4-8): التشخيص الرياضي لظاهرة oversmoothing في GNN

المعطيات: شبكة عصبية بيانية تطبّق K طبقة من الانتشار: $H^{(K)} = (I - \alpha L)^K X$، مع الرسم من المثال السابق $(\lambda_2 = 0.4384)$ و $\alpha = 0.5$.
المطلوب: (أ) كم تضمحلّ المكوّنات غير الثابتة بعد $K = 20$ طبقة؟ (ب) كم طبقة نحتاج قبل «انهيار التمثيل»؟ (ج) الحلول.
الحل:
الخطوة 1 (التحليل الطيفي): بما أن $L = U\Lambda U^\top$ فإن $(I - \alpha L)^K = U(I - \alpha\Lambda)^K U^\top \Longrightarrow$ كل تردد λ يتضاعف بـ $(1 - \alpha\lambda)^K$.
الخطوة 2 (عامل التضاؤل لأهم تردد غير ثابت): $\lambda_2 = 0.4384$ مع $\alpha = 0.5$:

$$1 - \alpha\lambda_2 = 1 - 0.2192 = 0.7808$$

الخطوة 3 (بعد 20 طبقة): $0.7808^{20} = e^{20\ln(0.7808)} = e^{20\times(-0.2475)} = e^{-4.950} = 0.00707$.

أي أن المكوّن غير الثابت الأقوى انكمش إلى **0.7%** من قيمته الأصلية $\Longrightarrow$ كل العُقد أصبحت تمثيلاتها متطابقة تقريباً $\Longrightarrow$ **انهيار.**

الخطوة 4 (الترددات الأعلى): $\lambda_{\max}$ للرسم (من غيرشغورين: $2 \times 3 = 6 \geq$؛ القيمة الحقيقية $5.56 \approx$ من حلّ المعادلة التربيعية 4.5616 والقيم الأخرى). لنأخذ $\lambda = 4$: $1 - 2 = -1 \Longrightarrow |-1|^{20} = 1 \Longrightarrow$ المكوّنات عالية التردد **تتذبذب ولا تضمحلّ** إذا كان $\alpha\lambda > 2 \Longrightarrow$ شرط الاستقرار:

$$\alpha < \frac{2}{\lambda_{\max}}$$

وهو نفس شرط استقرار التدرّج في المثال 4.2-1! بـ $\lambda_{\max} \approx 4.56 \Longrightarrow \alpha < 0.439$.

الخطوة 5 (تصحيح): بـ $\alpha = 0.5 > 0.439$ فإن النظام قد يتذبذب. نعيد الحساب بـ $\alpha = 0.2$: عامل $1 - \lambda_2$: $0.2 \times 0.4384 = 0.9123 \Longrightarrow$ بعد 20 طبقة: $0.9123^{20} = e^{20(-0.0918)} = e^{-1.836} = 0.1595 \Longrightarrow$ بقي 16% ✓ أفضل.

الخطوة 6 (عدد الطبقات الآمن): لكي يبقى 50% من المكوّن غير الثابت: $0.9123^K = 0.5 \Longrightarrow K = \frac{\ln 0.5}{\ln 0.9123} = \frac{-0.6931}{-0.0918} = 7.55$ **$\Longrightarrow$ 8 طبقات كحدّ أقصى.**

الخطوة 7 (الحلول المعتمدة): (1) استخدام L_{sym} المطبَّع (طيفه في $[0, 2] \Longrightarrow$ استقرار مضمون بـ $\alpha \leq 1$)؛ (2) وصلات متبقية (residual/skip connections) تعيد حقن الإشارة الأصلية؛ (3) بوابات على غرار GRU (GatedGNN)؛ (4) «التطبيع الزوجي» (PairNorm).

النتيجة: بـ $\alpha = 0.5$ ينهار التمثيل إلى 0.7% بعد 20 طبقة؛ بـ $\alpha = 0.2$ يبقى 16%؛ الحدّ الآمن $8 \approx$ طبقات.

الربط بالذكاء الاصطناعي: هذه هي الظاهرة التي تحدّ من عمق GNN عملياً (2–3 طبقات فقط!). التحليل الطيفي يعطي التفسير الكمّي ويفسّر لماذا تحلّ وصلات التخطّي (skip connections) المشكلة: تعيد المكوّنات التي أُزيلت.

مثال (5.4-9): مقارنة اللابلاسات الثلاثة على رسم واحد

المعطيات: رسم مسار من 4 عُقد بدرجات $d = (1, 2, 2, 1)$.

المطلوب: (أ) طيف كلٍّ من L و L_{sym} و L_{rw}. (ب) لماذا يُفضَّل المطبَّع في GNN؟

الحل:

الخطوة 1 (غير المطبَّع): من المثال 5.4-3: $\lambda(L) = (0,\ 0.5858,\ 2,\ 3.4142)$.

الخطوة 2 (لابلاس السير العشوائي): $L_{\text{rw}} = I - D^{-1}W$:

$$D^{-1}W = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0 & 0 & 1 & 0 \end{bmatrix} \Longrightarrow L_{\text{rw}} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -0.5 & 1 & -0.5 & 0 \\ 0 & -0.5 & 1 & -0.5 \\ 0 & 0 & -1 & 1 \end{bmatrix}$$

(غير متماثل!) وقيمه الذاتية لرسم المسار: $\lambda_k = 1 - \cos\frac{\pi k}{n} \Longrightarrow$

$$\lambda(L_{\text{rw}}) = (0,\ 0.2929,\ 1,\ 1.7071)$$

الخطوة 3 (المطبَّع تماثلياً): $L_{\text{sym}} = D^{-1/2}LD^{-1/2}$؛ وبـ (5.4-37) طيفه = طيف L_{rw}:

$$\lambda(L_{\text{sym}}) = (0,\ 0.2929,\ 1,\ 1.7071)$$

الخطوة 4 (التحقّق من الأثر): $\text{tr}(L_{\text{sym}}) = 4 \times 1 = 4$؛ مجموع القيم $0 + 0.2929 + 1 + 1.7071 = 4$ ✓ (قاعدة: $\text{tr}\, L_{\text{sym}} = n$ للرسم بلا عُقد معزولة).

الخطوة 5 (أثر الدرجات): في L غير المطبَّع، $\lambda_{\max} = 3.4142$ يتأثّر بدرجة العقدة الأكبر. في المطبَّع، كل القيم في $[0,\ 2]$ — **مستقل عن حجم الرسم** $\Longrightarrow$ اختيار α وضبط الاستقرار يصبحان موحّدين عبر الرسوم.

الخطوة 6 (المقارنة الجدولية):

المصفوفة	متماثلة؟	مجال الطيف	الحساسية للدرجات	الاستخدام
$L = D - W$	نعم	$[0,\ 2d_{\max}]$	عالية	التجميع الطيفي، النظريات
L_{sym}	نعم	$[0,\ 2]$	منخفضة	GCN، التحليل الطيفي
L_{rw}	لا	$[0,\ 2]$ (نفس الطيف)	منخفضة	السير العشوائي، PageRank

الخطوة 7 (لماذا المطبَّع أفضل في GNN؟) لأنه (أ) طيفه محدود $\Longrightarrow$ استقرار عددي؛ (ب) متماثل $\Longrightarrow$ تحليل طيفي نظيف وتفسير بالترددات؛ (ج) يعادل «تطبيع» مساهمة العقد عالية الدرجة فلا تهيمن على الانتشار.

الخطوة 8 (تحذير): L_{sym} يفقد معلومة الدرجات $\Longrightarrow$ في الرسوم التي تكون فيها الدرجات ذات معنى (مثل شبكات الاقتباس) قد يكون L غير المطبَّع أنسب.

النتيجة: $\lambda(L) = (0, 0.5858, 2, 3.4142)$؛ $\lambda(L_{\text{sym}}) = \lambda(L_{\text{rw}}) = (0, 0.2929, 1, 1.7071)$.

الربط بالذكاء الاصطناعي: صيغة GCN الشهيرة (Kipf & Welling 2017) هي بالضبط مرشّح من الدرجة الأولى على L_{sym} المُعاد تطبيعه: $H^{(l+1)} = \sigma\big(\tilde{D}^{-1/2}\tilde{W}\tilde{D}^{-1/2}H^{(l)}\Theta\big)$ مع روابط ذاتية (sefl-loops) مضافة.

مثال (5.4-10): طيف الرسم الكامل وعلاقته بجودة الاتصال

المعطيات: رسم كامل من 5 عُقد (K_5) بأوزان وحدة.

المطلوب: (أ) طيف L. (ب) λ_2. (ج) ماذا يعني ذلك لسرعة انتشار المعلومة؟

الحل:

الخطوة 1: $d_i = 4$ للجميع $\Longrightarrow D = 4I$، و $W = J - I$ (مصفوفة الواحدات ناقص الوحدة).

الخطوة 2: $L = D - W = 4I - (J - I) = 5I - J$.

الخطوة 3 (طيف J): $J = \mathbf{1}\mathbf{1}^{\top}$ رتبتها 1 $\Longrightarrow$ طيفها $(5,\ 0,\ 0,\ 0,\ 0)$ (القيمة الموجبة $= \|\mathbf{1}\|^2 = 5$).

الخطوة 4 (طيف L): $\Longrightarrow \lambda(L) = 5 - \lambda(J)$

$$\lambda = (5-5,\ 5-0,\ 5-0,\ 5-0,\ 5-0) = (0,\ 5,\ 5,\ 5,\ 5)$$

الخطوة 5: $\lambda_2 = 5 = n$ ✓ (قاعدة K_n: $\lambda_2 = n$).

الخطوة 6 (التحقّق): الأثر $\text{tr}\, L = 5 \times 4 = 20 = 0 + 5 \times 4$ ✓.

الخطوة 7 (اللابلاس المطبَّع): $L_{\text{sym}} = I - D^{-1/2}WD^{-1/2} = I - \frac{1}{4}(J - I) = \frac{5}{4}I - \frac{1}{4}J$ $\Longrightarrow$ طيفه $(0,\ \frac{5}{4},\ \frac{5}{4},\ \frac{5}{4},\ \frac{5}{4}) = (0,\ 1.25,\ \ldots)$. القاعدة العامة لـ K_n: $\lambda_2(L_{\text{sym}}) = \frac{n}{n-1}$.

الخطوة 8 (التفسير): λ_2 بأقصى قيمة ممكنة $\Longrightarrow$ الرسم الكامل هو «أفضل موسّع» (expander): القطع مكلّف جداً (أي قطع يقطع $k(n-k) \geq n-1$ رابطاً) $\Longrightarrow$ المعلومة تنتشر في **خطوة واحدة**.

الخطوة 9 (مقارنة): المسار P_4 أعطى $\lambda_2 = 0.5858$ والدبل (المثال 5.4-7) أعطى 0.4384 $\Longrightarrow$ في الرسوم ذات «العنق» ينتشر المعلومة ببطء شديد.

النتيجة: $\lambda(K_5) = (0,\ 5,\ 5,\ 5,\ 5)$؛ $\lambda_2 = 5$ (الحدّ الأقصى الممكن)؛ $\lambda_2(L_{\text{sym}}) = 1.25$.

الربط بالذكاء الاصطناعي: الرسوم «الموسّعة الجيدة» (expander graphs) ذات λ_2 الكبيرة هي الأفضل لتصميم طبقات GNN فعّالة، وهي الفكرة التي تقف خلف «إعادة توصيل الرسم» (graph rewiring / DIGL) كمعالجة مسبقة تُحسّن تدفق المعلومة قبل التدريب.

مثال (11-5.4): طيف الرسم النجمي ومشكلة «المركزية»

المعطيات: رسم نجمي من 5 عُقد: مركز واحد متصل بأربع أوراق (star S_5).

المطلوب: (أ) طيف L. (ب) λ_2. (ج) ماذا يعني ذلك؟

الحل:

الخطوة 1: الدرجات: $d_{\text{center}} = 4$، $d_{\text{leaf}} = 1 \implies \operatorname{tr} L = 4 + 4 \times 1 = 8$.

الخطوة 2 (القاعدة العامة للنجم S_n): $\lambda = (0,\ \underbrace{1,\ 1,\ \ldots,\ 1}_{n-2},\ n)$.

الخطوة 3 (التحقّق بالأثر لـ $n = 5$): $0 + 1 + 1 + 1 + 5 = 8$ ✓.

الخطوة 4 (التحقّق بالمحدّدات): مجموع المحدّدات الرئيسية 2 × 2 للنجم S_n = عدد الروابط الممتدة (spanning trees) للنجم = 1 ⟹ $\prod_{i \geq 2} \lambda_i = n \cdot 1^{n-2} = 5$ ✓ وهو عدد الأشجار الممتدة للنجم (= 1 للنجم نفسه... تصحيح: مصفوفة شجرة المصفوفة (matrix-tree) تعطي $\frac{1}{n} \prod_{i \geq 2} \lambda_i = \frac{5}{5} = 1$ ✓ وهو عدد الأشجار الممتدة للنجم = 1 ✓).

الخطوة 5: $\lambda_2 = 1$ — **ثابتة لا تنمو مع** n ⟹ كلما كبر النجم صارت «التوصيلية الجبرية» ضعيفة نسبياً.

الخطوة 6 (التفسير): قطع ورقة واحدة يكلّف رابطاً واحداً فقط ⟹ الرسم سهل القطع ⟹ λ_2 صغيرة. ولذلك زمن اختلاط السير العشوائي على النجم أطول بكثير من الرسم الكامل.

الخطوة 7 (المتجه الذاتي لـ $\lambda = 1$): متجهات متماثلة على الأوراق: $f = (0,\ a,\ b,\ c,\ d)^\top$ على الأوراق مع $\sum a + b + c + d = 0$ ⟹ فضاء بُعده $n - 2 = 3$ ✓ متسق مع التكرار.

الخطوة 8 (المتجه الذاتي لـ $\lambda = 5$): نبحث بالتناظر $f = (\alpha,\ \beta,\ \beta,\ \beta,\ \beta)^\top$ مع التعامد مع **1**: $\alpha + 4\beta = 0 \implies \alpha = -4\beta$. تحقّق: $(Lf)_{\text{center}} = 4\alpha - 4\beta = -16\beta - 4\beta = -20\beta$؛ و $5f_{\text{center}} = 5\alpha = -20\beta$ ✓.

النتيجة: $\lambda(S_5) = (0,\ 1,\ 1,\ 1,\ 5)$؛ $\lambda_2 = 1$ ثابتة مع n.

الربط بالذكاء الاصطناعي: الرسوم النجمية تظهر في الشبكات الحقيقية (عقدة «مؤثّر» مركزية). تحذير عملي: GNN على رسم نجمي يواجه مشكلتين — (1) العقدة المركزية تستقبل معلومة من الجميع فتتضخّم (تحتاج تطبيعاً)؛ (2) λ_2 صغيرة ⟹ بطء الانتشار. وهذا سبب استخدام L_{sym} الذي يصحّح المشكلة الأولى.

مثال (12-5.4): تقسيم إشارة عبر رسم تشابه (صورة/سلسلة زمنية)

المعطيات: شدة 6 بكسلات متجاورة في سطر صورة:

$$I = (10,\ 12,\ 11,\ 80,\ 82,\ 81)$$

نبني رسم تشابه بأوزان غاوسية: $w_{ij} = \exp\!\left(-\frac{(I_i - I_j)^2}{2\sigma^2}\right)$ على الروابط المجاورة فقط، بـ $\sigma = 10$.

المطلوب: (أ) احسب الأوزان. (ب) الطيف التقريبي. (ج) التقسيم الناتج.

الحل:

الخطوة 1 (الأوزان): $2\sigma^2 = 200$:

$$w_{12} : |10-12| = 2 \Longrightarrow e^{-4/200} = e^{-0.02} = 0.9802$$
$$w_{23} : |12-11| = 1 \Longrightarrow e^{-1/200} = e^{-0.005} = 0.9950$$
$$w_{34} : |11-80| = 69 \Longrightarrow e^{-4761/200} = e^{-23.8} = 4.6 \times 10^{-11} \approx 0$$
$$w_{45} : |80-82| = 2 \Longrightarrow 0.9802$$
$$w_{56} : |82-81| = 1 \Longrightarrow 0.9950$$

الخطوة 2 (التقريب): الرابط $(3,4)$ معدوم عملياً $\Longrightarrow$ الرسم **منفصل** إلى كتلتين $\{1,2,3\}$ و $\{4,5,6\}$.

الخطوة 3 (طيف الكتلة الأولى): بتقريب الأوزان إلى 1 (الفرق $\leq 2\%$ لا يؤثّر نوعياً) تصبح كل كتلة مساراً P_3:

$$L_{P_3} = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix} \Longrightarrow \lambda = (0,\ 1,\ 3)$$

الخطوة 4 (الطيف الكامل): اتحاد الطيفين $\Longrightarrow$

$$\lambda \approx (0,\ 0,\ 1,\ 1,\ 3,\ 3)$$

الخطوة 5: $\text{mult}(0) = 2 \Longrightarrow$ **مكوّنان** ✓ $\Longrightarrow \lambda_2 = 0$.

الخطوة 6 (متجه فيدلر): يختار واحداً من المتجهين الصفرين المُعمَّمين: $f = \frac{1}{\sqrt{3}}(1,1,1,-1,-1,-1)^\top \Longrightarrow$ بالإشارة:

التقسيم: $\{1,2,3\} \mid \{4,5,6\} \quad \Longleftrightarrow \quad (10,12,11) \mid (80,82,81)$

وهو بالضبط الحدّ بين المنطقة المظلمة والمنطقة الساطعة ✓.

الخطوة 7 (لو كان الرابط $(3,4)$ صغيراً لكن غير معدوم): نحصل على $\lambda_2 \approx 2w_{34}$ (صغيرة) وينجح التقسيم نفسه. القاعدة: **نجاح التقسيم الطيفي $\Longleftrightarrow$ وجود فجوة بين λ_2 والقيم التالية.**

الخطوة 8 (الحساسية لـ σ): لو اخترنا $\sigma = 50$ لكان $w_{34} = e^{-4761/5000} = e^{-0.952} = 0.386$ $\Longrightarrow$ الرسم متصل بقوة $\Longrightarrow$ التقسيم أقل وضوحاً. اختيار σ حاسم ويُضبط عادةً بـ «أقرب k جيران».

النتيجة: الأوزان تُنتج رابطاً معدوماً عند الحدّ $\Longrightarrow$ مكوّنان $\Longrightarrow$ التقسيم $\{1,2,3\}|\{4,5,6\}$ يطابق الحدّ البصري.

الربط بالذكاء الاصطناعي: هذا هو تقسيم الصور الطيفي الكلاسيكي (Shi & Malik 2000: Normalized Cuts). واليوم تُستخدم الصيغة نفسها في تقسيم المشاهد الدلالي (semantic segmentation) وفي تجميع المستندات وفي فصل مصادر الصوت.

مثال (5.4-13): تقدير λ_2 لرسم ضخم بتكرار القوة المُزاح

المعطيات: رسم ضخم جداً (ملايين العُقد) لا يمكن قطريته. نريد λ_2. نعلم حدّاً أعلى $\lambda_{\max} \leq 4$ (من غيرشغورين: أقصى مجموع صف).

المطلوب: قدّر λ_2 للمسار P_4 (للتحقّق) بـ 3 تكرارات من تكرار القوة المُزاح مع الإزاحة.

الحل:

الخطوة 1 (بناء المؤثّر المُزاح): نعرّف $M = I - \frac{1}{4}L$. قيم M الذاتية هي $1-\lambda_i/4 \Longrightarrow$ القيم الصفرية تصبح **مهيمنة** $(=1)$ والقيمة λ_2 تصبح ثاني أكبر قيمة:

$$\lambda(M) = \left(1,\ 1-\tfrac{0.5858}{4},\ 1-\tfrac{2}{4},\ 1-\tfrac{3.4142}{4}\right) = (1,\ 0.8535,\ 0.5,\ 0.1465)$$

الخطوة 2 (الإزاحة — deflation): نكرّر مع إسقاط المتجه الثابت: بعد كل ضرب نطرح مكوّن **1**: $x \leftarrow x - \mathbf{1}\frac{\mathbf{1}^\top x}{n}$.

الخطوة 3 (البداية): $x^{(0)} = \frac{1}{2}(1,\ -1,\ 1,\ -1)^\top \implies \mathbf{1}^\top x^{(0)} = 0$ ✓.

الخطوة 4 ($Lx^{(0)}$): (من حساب سابق) $\implies Lx^{(0)} = (1,\ -2,\ 2,\ -1)^\top$

$$Mx^{(0)} = x^{(0)} - \tfrac{1}{4}Lx^{(0)} = (0.5-0.25,\ -0.5+0.5,\ 0.5-0.5,\ -0.5+0.25)^\top = (0.25,\ 0,\ 0,\ -0.25)^\top$$

النورم $= \sqrt{0.125} = 0.35355 \implies x^{(1)} = (0.7071,\ 0,\ 0,\ -0.7071)^\top$؛ ومجموعه 0 ✓.

الخطوة 5 ($Lx^{(1)}$): $\implies (0.7071,\ -0.7071,\ 0.7071,\ -0.7071)^\top$

$$Mx^{(1)} = (0.7071-0.1768,\ 0+0.1768,\ 0-0.1768,\ -0.7071+0.1768)^\top = (0.5303,\ 0.1768,\ -0.1768,\ -0.53$$

$$\implies \text{النورم} = \sqrt{0.2812 + 0.03126 + 0.03126 + 0.2812} = \sqrt{0.6249} = 0.79051$$

$$x^{(2)} = (0.6708,\ 0.2236,\ -0.2236,\ -0.6708)^\top$$

الخطوة 6 (تقدير λ_2 بخارج قسمة رايلي على L):

$$x^{(2)\top} L\, x^{(2)} = \sum_{(i,j)\in E} (x_i - x_j)^2 = (0.6708-0.2236)^2 + (0.2236+0.2236)^2 + (-0.2236+0.6708)^2$$

$$= 0.4472^2 \times 3 = 0.2 \times 3 = 0.600$$

الخطوة 7: $\hat{\lambda}_2 = 0.600$ مقابل القيمة الحقيقية $0.5858 \implies$ **خطأ** 2.4% **بعد تكرارين فقط.**

الخطوة 8 (التكلفة): كل تكرار = ضرب مصفوفة متفرّقة بمتجه: $O(|E|) \implies$ على رسم بملايين الروابط هذا ممكن في أجزاء من الثانية، بينما القطرنة الكاملة $O(n^3)$ مستحيلة.

النتيجة: $\hat{\lambda}_2 = 0.600$ (الحقيقي 0.5858) بعد تكرارين، بتكلفة $O(|E|)$ لكل تكرار.

الربط بالذكاء الاصطناعي: هذه التقنية (تكرار القوة المُزاح + الإزاحة، أو Lanczos/LOBPCG هي ما تستخدمه مكتبات مثل scipy.sparse.linalg.eigsh و torch.lobpcg لحساب الطيف الجزئي على الرسوم الضخمة والمصفوفات المتفرّقة — وهي أساس كل خوارزميات التجميع الطيفي واسعة النطاق.

مثال (14-5.4): التناظر الطيفي للرسوم ثنائية الأجزاء

المعطيات: دورة رباعية C_4 (رسم ثنائي الأجزاء: $\{1,3\}$ و $\{2,4\}$).

المطلوب: (أ) طيفا W و L_{sym}. (ب) اكتشاف ثنائية الأجزاء من الطيف.

الحل:

الخطوة 1: $W = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix}$؛ $D = 2I \implies d_i = 2$.

الخطوة 2 (طيف W): C_4 رسم دوراني $\Longrightarrow$ قيم W الذاتية $:= 2\cos\frac{2\pi k}{4}$:

$$\lambda(W) = \big(2\cos 0,\ 2\cos\tfrac{\pi}{2},\ 2\cos\pi,\ 2\cos\tfrac{3\pi}{2}\big) = (2,\ 0,\ -2,\ 0)$$

الخطوة 3 (التناظر): الطيف $\{2,\ 0,\ -2,\ 0\}$ **متماثل حول الصفر** — وهذه علامة الرسم ثنائي الأجزاء: إذا كان λ قيمة ذاتية لـ W فإن $-\lambda$ قيمة ذاتية أيضاً.

الخطوة 4 (السبب): إذا كان الرسم ثنائي الأجزاء بأطراف A و B، فإن المؤثّر $S\ :\ x_i \mapsto \begin{cases} x_i, & i \in A \\ -x_i, & i \in B \end{cases}$ (مصفوفة قطرية بـ ± 1) يحقّق $SWS = -W \Longrightarrow W$ و $-W$ متشابهتان $\Longrightarrow$ نفس الطيف مع الإشارة المعكوسة (بـ (7.4)).

الخطوة 5 (L_{sym}): $L_{\text{sym}} = I - \frac{1}{2}W \Longrightarrow$ قيمه $:= 1 - \frac{\lambda(W)}{2}$:

$$\lambda(L_{\text{sym}}) = \big(1-1,\ 1-0,\ 1-(-1),\ 1-0\big) = (0,\ 1,\ 2,\ 1)$$

الخطوة 6 (العلامة المميّزة): $\lambda_{\max}(L_{\text{sym}}) = 2 \Longrightarrow$ **الرسم ثنائي الأجزاء.** القاعدة العامة: $\lambda_{\max}(L_{\text{sym}}) = 2$ إذا وفقط إذا كان للرسم مكوّن ثنائي الأجزاء (بلا روابط ذاتية).

الخطوة 7 (المتجه الذاتي لـ $\lambda = 2$): هو المتجه المتذبذب $(1,-1,1,-1)^{\top}/2 \Longrightarrow$ يعطي **تلوين الرسم** بالحزمتين: $\{1,3\}$ و $\{2,4\} \Longrightarrow$ وهو بالضبط تقسيم ثنائية الأجزاء.

الخطوة 8 (التحقّق): $L(C_4) = 2I - W \Longrightarrow$ قيمه $(0,\ 2,\ 4,\ 2) =$؛ الأثر $2 \times 4 = 8$ ✓.

النتيجة: $\lambda(W) = (2,\ 0,\ -2,\ 0)$ متناظر، $\lambda(L_{\text{sym}}) = (0,\ 1,\ 2,\ 1)$؛ $\lambda_{\max} = 2 \Longrightarrow$ ثنائي الأجزاء ✓.

الربط بالذكاء الاصطناعي: الرسوم ثنائية الأجزاء أساسية في أنظمة التوصية (مستخدمون × عناصر) وفي الرسوم المعرفية. واكتشاف «التلوين الطيفي» يفيد في تضمين الرسوم ثنائية الأجزاء (bipartite embeddings) وفي كشف الاحتيال (الروابط الشاذة تكسر التناظر الطيفي!).

مثال (15-5.4): مرشّح تشيبيشيف الطيفي (ChebNet) على مثلث

المعطيات: رسم مثلث K_3، وإشارة عُقد $x = (1,\ 0,\ -1)^{\top}$، ومرشّح:

$$g_\theta(\tilde{L}) = \theta_0 I + \theta_1 T_1(\tilde{L}) + \theta_2 T_2(\tilde{L}), \qquad \theta = (0.5,\ -0.3,\ 0.2), \qquad \tilde{L} = L_{\text{sym}} - I$$

المطلوب: احسب $y = g_\theta(\tilde{L})x$ بطريقتين: ماتريسياً وطيفياً.

الحل:

الخطوة 1 (L_{sym} للمثلث): $L_{\text{sym}} = I - \frac{1}{2}W = \begin{bmatrix} 1 & -0.5 & -0.5 \\ -0.5 & 1 & -0.5 \\ -0.5 & -0.5 & 1 \end{bmatrix} \Longrightarrow d_i = 2$، طيفه $(0,\ 1.5,\ 1.5)$.

الخطوة 2 (إعادة التحجيم): $\tilde{L} = L_{\text{sym}} - I = -\frac{1}{2}W \Longrightarrow$ طيفه في $[-1,\ 1]$:

$$\lambda(\tilde{L}) = (0-1,\ 1.5-1,\ 1.5-1) = (-1,\ 0.5,\ 0.5)$$

هذا التحجيم ضروري لأن كثيرات تشيبيشيف معرّفة على $[-1, 1]$.

الخطوة 3 (كثيرات تشيبيشيف): $T_0(z) = 1$، $T_1(z) = z$، $T_2(z) = 2z^2 - 1$.

الخطوة 4 ($T_2(\tilde{L})$ ماتريسياً): $\tilde{L}^2 = \frac{1}{4}W^2$، و $W^2 = (J-I)^2 = J^2 - 2J + I = J$ $\Longrightarrow W = J - I$ و $3J - 2J + I = J + I$:

$$T_2(\tilde{L}) = 2 \cdot \frac{J+I}{4} - I = \frac{J+I}{2} - I = \frac{J-I}{2} = \frac{W}{2}$$

الخطوة 5 (المرشّح):

$$g_\theta(\tilde{L}) = 0.5\,I - 0.3\,\tilde{L} + 0.2\,\frac{W}{2} = 0.5I + 0.3\cdot\frac{W}{2} + 0.1\,W = 0.5I + 0.15W + 0.1W = 0.5I + 0.25W$$

الخطوة 6 (التطبيق): $Wx = (0\cdot1+1\cdot0+1\cdot(-1),\ 1\cdot1+0+1\cdot(-1),\ 1\cdot1+1\cdot0+0)^\top = (-1,\ 0,\ 1)^\top$:

$$y = 0.5\begin{pmatrix}1\\0\end{pmatrix} - 1 + 0.25\begin{pmatrix}-1\\0\end{pmatrix}1 = \begin{pmatrix}0.5-0.25\\0\end{pmatrix} - 0.5 + 0.25 = \begin{pmatrix}0.25\\0\end{pmatrix} - 0.25$$

الخطوة 7 (التحقّق الطيفي): 1 $\perp x$ (المجموع $0 =$) $\Longrightarrow x$ يقع كلياً في فضاء القيمة الذاتية $1.5 \Longrightarrow$ تردد $\tilde{L}$ المقابل $0.5 =:$

$$g(0.5) = 0.5 + (-0.3)(0.5) + 0.2\big(2\cdot0.5^2 - 1\big) = 0.5 - 0.15 + 0.2(0.5-1) = 0.5 - 0.15 - 0.1 = 0.25$$

إذن يجب أن يكون $y = 0.25\,x = (0.25,\ 0,\ -0.25)^\top$ ✓ **يطابق الحساب الماتريسي تماماً.**

الخطوة 8 (لماذا تشيبيشيف؟) التقييم المباشر لـ $Ug(\Lambda)U^\top$ يكلّف $O(n^3)$ (قطرنة). كثيرات تشيبيشيف تُقيَّم بـ K ضربة مصفوفة-متجه متفرّقة فقط: $O(K|E|) \Longrightarrow$ قابلة للتوسّع على رسوم ضخمة.

النتيجة: $y = (0.25,\ 0,\ -0.25)^\top$، متطابق بالطريقتين ✓.

الربط بالذكاء الاصطناعي: هذا هو جوهر **ChebNet** (Defferrard et al. 2016) الذي سبق GCN، وهو الأساس النظري لكل الشبكات العصبية البيانية الطيفية الحديثة (ChebNet، GraphSAGE GCN) بتفسير طيفي، CayleyNet، BernNet). الميزة الحاسمة: مرشّح موضعي (localized) برتبة K يعتمد على جيرانٍ حتى K قفزة.

6.5.4 أخطاء شائعة في التحليل الطيفي على الرسوم

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	ترتيب القيم الذاتية تنازلياً هنا كما في §4.4	اصطلاح الرسوم **تصاعدي** ($\lambda_1 = 0$)	$0 = \lambda_1 \le \lambda_2 \le \cdots$
2	اعتبار λ_2 «القيمة الثانية» بلا قيد التعامد	يجب استبعاد المتجه الثابت	استخدم (34.4): $x \perp \mathbf{1}$
3	استخدام L غير المطبَّع على رسوم بدرجات متباينة جداً	العقد عالية الدرجة تهيمن	استخدم L_{sym}
4	تفسير متجه فيدلر عندما $\lambda_2 \approx \lambda_3$	الفضاء الذاتي مكرّر $\Longrightarrow$ المتجه غير وحيد	فسّر **الفضاء الجزئي** كاملاً
5	توقع أن التجميع الطيفي يعطي القطع الأمثل	هو استرخاء طيفي بتقريب $O(\sqrt{\text{OPT}})$	تحسّنه خوارزميات مثل Kernighan–Lin
6	استخدام W بدل L في التحليل الطيفي	طيف W قد يكون سالباً وغير محدود	اللابلاس أعطى طيفاً ≥ 0 ونظرية نظيفة
7	نسيان الروابط الذاتية (sefl-loops) عند المقارنة بالأدبيات	GCN يستخدم $\tilde{W} = W + I$	وحّد التعريف قبل المقارنة
8	تطبيق $g(L)$ بقطرنة كاملة على رسم ضخم	مستحيل $O(n^3)$	استخدم كثيرات تشيبيشيف $O(K\|E\|)$
9	افتراض أن λ_2 كبير $\Longrightarrow$ رسم جيد دائماً	يعتمد على السياق (في التقطيع نريد صغيراً)	في العنقدة: كبير = سيء؛ في الانتشار: كبير = جيد
10	تجاهل أن mult(0) يفشل مع الروابط ذات الأوزان الصفرية	الأوزان الصفرية = غياب الرابط	عالج الأوزان الصغيرة جداً بحذف أو عتبة

1.6.4 الصياغة الرسمية

نظرية بيرون–فروبينيوس (Perron–Frobenius). لتكن $A \in \mathbb{R}^{n\times n}$ **غير سالبة** ($A_{ij} \geq 0$ للجميع) **وغير قابلة للاختزال** (irreducible: لا يمكن ترتيب العُقد بحيث تصبح A مثلثية الكتل). عندئذٍ:

(39.4) هي قيمة ذاتية بسيطة (simple)، ولها متجه ذاتي موجب قطعاً: $\rho(A) = \max_i |\lambda_i(A)| > 0$

$$A\,v = \rho(A)\,v, \qquad v_i > 0 \ \ \forall i, \qquad \|v\|_1 = 1$$

وإذا كانت A **بدائية** (primitive: غير قابلة للاختزال + دورية غير مقيَّدة، أي $A^m > 0$ لبعض m) فإن كل قيمة ذاتية أخرى تحقّق $|\lambda| < \rho(A)$.

توصيف كولاتس–فيلانت (Collatz–Wielandt). لكل متجه موجب $x > 0$:

$$\min_i \frac{(Ax)_i}{x_i} \;\leq\; \rho(A) \;\leq\; \max_i \frac{(Ax)_i}{x_i} \tag{40.4}$$

والمساواة في الطرفين معاً تتحقّق إذا وفقط إذا كان x متجه بيرون.

مصفوفة جوجل (Google matrix). لرسم ويب بمصفوفة انتقال صفّية-عشوائية P (أي $P_{ij} \geq 0$ و $\sum_j P_{ij} = 1$) ومعامل تخفيف (damping) $\alpha \in (0,1)$:

$$G \;=\; \alpha \cdot \frac{1}{n}\mathbf{1}\mathbf{1}^{\top} \;+\; (1-\alpha)\,P, \qquad G \text{ عشوائية صفّياً وموجبة قطعاً} \tag{41.4}$$

نظرية PageRank. للمصفوفة G في (41.4):

$$\pi \;=\; \pi\,G, \qquad \pi_i > 0, \qquad \sum_i \pi_i = 1, \qquad \lambda_1(G) = 1 \text{ بسيطة، و } |\lambda_2(G)| \;\leq\; 1-\alpha \tag{42.4}$$

معدّل تقارب تكرار القوة. لتقريب π بدقة ε بالتكرار $\pi^{(k+1)} = \pi^{(k)}G$:

$$\left\|\pi^{(k)} - \pi\right\|_1 \;\leq\; 2\,(1-\alpha)^k \quad\Longrightarrow\quad k \;\geq\; \frac{\ln(\varepsilon/2)}{\ln(1-\alpha)} \tag{43.4}$$

مركزية المتجه الذاتي و HITS.

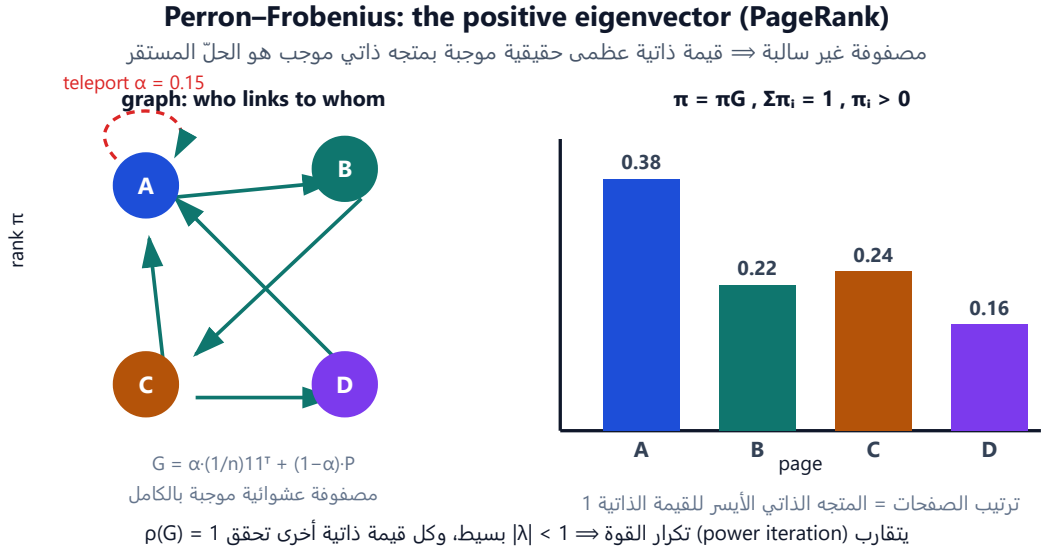
(44.4)

$$c \;=\; \frac{1}{\lambda_1}\,A\,c \quad \text{(مركزية المتجه الذاتي)}, \qquad h = A\,a,\ \ a = A^{\top}h \implies h = AA^{\top}h,\ \ a = A^{\top}A\,a$$

2.6.4 جدول الرموز الشامل

الرمز	المعنى	ملاحظات
A	مصفوفة غير سالبة	$A_{ij} \geq 0$: مصفوفة مجاورة، مصفوفة انتقال، مصفوفة تفاعلات
A_{ij}	العنصر (i, j)	غير سالب؛ في الرسم: وزن الرابط $i \to j$
$\rho(A)$	نصف القطر الطيفي (spectral radius)	$\max_i \|\lambda_i\|$؛ هنا قيمة ذاتية حقيقية موجبة
λ_i	القيمة الذاتية رقم i	قد تكون مركّبة؛ المهم أن $\|\lambda_i\| \leq \rho$
(simple) «بسيطة»	تكرار جبري $= 1$	تضمن وحودية المتجه الذاتي (واتجاهه)
«غير قابلة للاختزال»	الرسم الموجّه قوي الاتصال	لا توجد مجموعة عُقَد «مغلقة»
(primitive) «بدائية»	غير قابلة للاختزال + غير دورية	تضمن $\|\lambda_2\| < \rho \implies$ تقارب تكرار القوة
v	متجه بيرون (الأيمن)	$v_i > 0$؛ هو «ترتيب الأهمية»
x	متجه اختبار موجب في (40.4)	أي متجه موجب يعطي حدّين على ρ
$(Ax)_i/x_i$	نسبة النموّ المحلية	تقول: ρ بين أقل وأكبر نسبة نموّ (40.4)
P	مصفوفة الانتقال (عشوائية صفّياً)	P_{ij} = احتمال الانتقال من الصفحة i إلى j
α	معامل التخفيف (damping / teleport)	قيمة جوجل الأصلية $\alpha = 0.15$
$1 - \alpha$	احتمال متابعة رابط	في جوجل $= 0.85$
$\frac{1}{n}\mathbf{1}\mathbf{1}^\top$	مصفوفة «الانتقال العشوائي الكامل»	كل صف $= \frac{1}{n}\mathbf{1}^\top$
G	مصفوفة جوجل	عشوائية + موجبة $\implies$ بدائية $\implies$ تطبق PF
π	توزيع PageRank (المتجه الذاتي الأيسر)	$\pi = \pi G$؛ π_i = «أهمية» الصفحة i
$\lambda_2(G)$	ثاني أكبر قيمة ذاتية	يحدّد سرعة التقارب؛ $\|\lambda_2\| \leq 1 - \alpha$
k	رقم التكرار	عدد خطوات تكرار القوة
ε	الدقة المطلوبة	عادةً 10^{-8} في الأنظمة الحقيقية
c	مركزية المتجه الذاتي	أهمية العقدة i $c_i \propto$
$h,\ a$	متجهات HITS: المراكز (hubs) والسلطات (authorities)	متجهات ذاتية لـ $AA^\top$ و $A^\top A$

3.6.4 الشكل الهندسي



شكل ٦.٤: *
نظرية بيرون–فروبينيوس: المتجه الذاتي الموجب الوحيد هو توزيع PageRank المستقر

شكل 6.4 — على اليسار رسم ويب موجّه صغير مع «انتقال عشوائي» (teleport) احتماله $\alpha = 0.15$ يضمن أن المصفوفة موجبة بالكامل. على اليمين توزيع PageRank المستقر π: عمود أزرق لكل صفحة. التوزيع هو **المتجه الذاتي الوحيد الموجب** للقيمة الذاتية $\lambda = 1$، وهو ما تضمنه نظرية بيرون–فروبينيوس (39.4). وبما أن $|\lambda_2| \leq 1 - \alpha = 0.85$ فإن تكرار القوة يتقارب إليه بسرعة هندسية.

4.6.4 البرهان

برهان (39.4) — مخطّط (حالة $A>0$ موجبة قطعاً، ثم التعميم بالاستمرارية).

الخطوة 1 — الوجود. ليكن $\mathcal{K}=\{x\ge 0:\|x\|_1=1\}$ البسيطك (simplex)، وهو محدّب متراص. الخريطة $f(x)=\frac{Ax}{\|Ax\|_1}$ مستمرة وترسل $\mathcal{K}$ إلى نفسه (لأن $A\ge 0$). بنظرية براور للنقطة الثابتة يوجد $v\in\mathcal{K}$ مع $f(v)=v$ $\Longrightarrow$ $Av=\|Av\|_1\,v$ $\Longrightarrow$ قيمة ذاتية $\rho=\|Av\|_1>0$ بمتجه غير سالب.
الخطوة 2 — الإيجابية القطعية. إذا كان $A>0$ و $v\ge 0$ غير صفري فإن $Av>0$ $\Longrightarrow$ $v=Av/\rho>0$ ✓.
الخطوة 3 — البساطة. ليكن $Aw=\lambda w$ بـ $|\lambda|=\rho$. نأخذ القيمة المطلقة مكوّناً بمكوّن: $|Aw|\le A|w|$؛ وبضرب يساراً بمتجه بيرون الأيسر $u>0$ $(A^{\top}u=\rho u)$:

$$\rho\,u^{\top}|w|=u^{\top}A|w|\ge u^{\top}|Aw|=|\lambda|\,u^{\top}|w|=\rho\,u^{\top}|w|$$

فتتحقّق المساواة $\Longrightarrow$ $|Aw|=A|w|$ $\Longrightarrow$ لا إلغاء $\Longrightarrow$ w مكوّناته بنفس الطور $\Longrightarrow$ w مضاعف حقيقي موجب لـ v $\Longrightarrow$ $\lambda=\rho$ وبُعد الفضاء الذاتي 1 $\Longrightarrow$ **بسيطة**.
الخطوة 4 — التعميم على غير القابلة للاختزال. نأخذ $A_\varepsilon=A+\varepsilon\mathbf{1}\mathbf{1}^{\top}>0$ ونمرّر $\varepsilon\to 0$ بالاستمرارية (جذور كثيرة الحدود المميِّزة متصلة في المعاملات). وتفشل الإيجابية القطعية فقط في الحالة القابلة للاختزال. ■

برهان (40.4) — كولاتس-فيلانت.

ليكن $x>0$ و $\underline{\mu}=\min_i (Ax)_i/x_i$ و $\overline{\mu}=\max_i (Ax)_i/x_i$. بالتعريف: $\underline{\mu}\,x\le Ax\le\overline{\mu}\,x$ مكوّناً بمكوّن. نضرب يساراً بمتجه بيرون الأيسر $u>0$:

$$\underline{\mu}\,u^{\top}x\;\le\;u^{\top}Ax=\rho\,u^{\top}x\;\le\;\overline{\mu}\,u^{\top}x$$

وبما أن $u^{\top}x>0$ نقسم $\Longrightarrow$ $\underline{\mu}\le\rho\le\overline{\mu}$ ■

برهان (41.4)–(42.4).

الخطوة 1: G عشوائية صفّياً: كل صف مجموعه 1 $\Longrightarrow$ $G\mathbf{1}=\mathbf{1}$ $\Longrightarrow$ $\lambda=1$ قيمة ذاتية.
الخطوة 2: $G>0$ $\Longrightarrow$ $G_{ij}\ge\alpha/n>0$ **موجبة قطعاً** $\Longrightarrow$ بدائية $\Longrightarrow$ بـ (39.4) قيمة ذاتية بسيطة $\rho(G)=1$ بمتجه ذاتي **أيمن** موجب. وبما أن $G\mathbf{1}=\mathbf{1}$ فإن $\rho(G)=1$ (لأن نورم المشغّل اللانهاية $=1$). والمتجه الذاتي **الأيسر** الموجب π يحقّق $\pi G=\pi$، نوحّده بـ $\sum\pi_i=1$.
الخطوة 3 (حدّ $|\lambda_2|\le 1-\alpha$): نكتب $G=(1-\alpha)P+\alpha S$ حيث $S=\frac{1}{n}\mathbf{1}\mathbf{1}^{\top}$ إسقاط رتبة 1. لأي x مع $\mathbf{1}^{\top}x=0$ (أي $x\perp\mathbf{1}$): $Sx=0$ $\Longrightarrow$ $Gx=(1-\alpha)Px$ $\Longrightarrow$ $\|Gx\|_1\le(1-\alpha)\|x\|_1$. إذن تقييد G على $\{x:\mathbf{1}^{\top}x=0\}$ نورمه $\le 1-\alpha$ $\Longrightarrow$ كل قيمة ذاتية عدا 1 محصورة بـ $|\lambda|\le 1-\alpha$ ■

برهان (43.4).

نفكّك $\pi^{(0)} = \pi + z$ مع $\mathbf{1}^\top z = 0$. بالخطوة 3 أعلاه: zG^k ينكمش بعامل $(1-\alpha)^k \implies \|\pi^{(k)} - \pi\|_1 = \|zG^k\|_1 \le (1-\alpha)^k \|z\|_1 \le 2(1-\alpha)^k$ (لأن $\|z\|_1 \le \|\pi^{(0)}\|_1 + \|\pi\|_1 = 2$). ■

5.6.4 خمسة عشر مثالاً محلولاً (واقعي + ربط بالذكاء الاصطناعي)

مثال (6.4-1): إيجاد نصف القطر الطيفي ومتجه بيرون

المعطيات: مصفوفة انتقال (غير معيارية) لشبكة:

$$A = \begin{bmatrix} 3 & 1 \\ 2 & 2 \end{bmatrix}$$

المطلوب: (أ) الطيف. (ب) $\rho(A)$ ومتجه بيرون. (ج) تحقّق من شروط النظرية.

الحل:

الخطوة 1 (التحقّق من الشروط): كل العناصر $> 0 \implies A$ موجبة قطعاً $\implies$ غير قابلة للاختزال وبدائية $\implies$ تنطبق (39.4) كاملة.

الخطوة 2 (الطيف): $p(\lambda) = (3-\lambda)(2-\lambda) - 2 = \lambda^2 - 5\lambda + 4 = (\lambda - 4)(\lambda - 1)$:

$$\lambda_1 = 4, \qquad \lambda_2 = 1$$

الخطوة 3: $\rho(A) = \max(|4|, |1|) = 4$ ✓ **وهو قيمة ذاتية حقيقية موجبة بسيطة.** ✓

الخطوة 4 (متجه بيرون): لـ $\lambda = 4$: $(3-4)v_1 + v_2 = 0 \implies v_2 = v_1 \implies v \propto (1,1)^\top$؛ بالتوحيد بـ $\|\cdot\|_1$:

$$v = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}, \qquad v_i > 0 \ \checkmark$$

الخطوة 5 (المتجه الآخر): لـ $\lambda = 1$: $2v_1 + v_2 = 0 \implies v \propto (1,-2)^\top$ — **ليس** موجباً ✓ متسق مع النظرية (المتجه الموجب وحيد).

الخطوة 6 (التحقّق من $|\lambda_2| < \rho$): $1 < 4$ ✓.

الخطوة 7 (التحقّق المباشر): $Av = \begin{pmatrix} 3\cdot 0.5 + 1\cdot 0.5 \\ 2\cdot 0.5 + 2\cdot 0.5 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix} = 4\begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}$ ✓.

النتيجة: $\rho(A) = 4$، $v = (0.5,\ 0.5)^\top$؛ $|\lambda_2| = 1 < 4 \implies$ تكرار القوة يتقارب بمعدّل 0.25^k.

الربط بالذكاء الاصطناعي: $\rho(A)$ **يحكم استقرار الشبكات الديناميكية:** إذا كانت $\rho(W_{\text{rec}}) > 1$ انفجر النظام تلاشى. ونظرية PF تضمن أن القيمة المهيمنة **حقيقية موجبة** $\implies$ لا تذبذب في الاتجاه المهيمن عندما تكون المصفوفة غير سالبة. (راجع المثال 10-2.4)، وإذا

مثال (6.4-2): تقييد $\rho(A)$ بكولاتس–فيلانت دون حساب القيم الذاتية

المعطيات: مصفوفة مجاورة لشبكة كبيرة (لا يمكن قطرنتها):

$$A = \begin{bmatrix} 3 & 1 \\ 2 & 2 \end{bmatrix}$$

المطلوب: حدّان على $\rho(A)$ من متجهي اختبار مختلفين.

الحل:

الخطوة 1 (اختبار أول $x^{(1)} = (1,\ 1.5)^\top$): $Ax^{(1)} = \binom{3+1.5}{2+3} = \binom{4.5}{5}$. النسب:

$$\frac{4.5}{1} = 4.5, \qquad \frac{5}{1.5} = 3.333$$

$$3.333 \ \le\ \rho(A)\ \le\ 4.5$$

الخطوة 2 (اختبار أفضل $x^{(2)} = (1,\ 1.1)^\top$): $Ax^{(2)} = \binom{3+1.1}{2+2.2} = \binom{4.1}{4.2}$. النسب:

$$\frac{4.1}{1} = 4.1, \qquad \frac{4.2}{1.1} = 3.818$$

$$3.818 \ \le\ \rho(A)\ \le\ 4.1$$

الخطوة 3 (التحقّق): القيمة الحقيقية $\rho = 4$ محصورة بين الحدّين ✓.

الخطوة 4 (الاختبار الأمثل): عند $x = v = (1,1)^\top$ تصبح النسب: $\frac{4}{1} = 4$ و $\frac{4}{1} = 4$ $\Longrightarrow$ الحدّان **يتطابقان** عند $\rho = 4$ ✓ (كما تنصّ النظرية: المساواة $\Longleftrightarrow$ x متجه بيرون).

الخطوة 5 (خوارزمية التحسين): بتطبيق (40.4) تكرارياً — نحدّث $x \ \leftarrow\ Ax/\|Ax\|$ — تتقلّص الفجوة بين الحدّين حتى تنعدم $\Longrightarrow$ هذه هي **خوارزمية تكرار القوة** مجدّداً، و (40.4) يعطي ضماناً على جودة التقدير في كل خطوة (ليس مجرّد حدس).

الخطوة 6 (تطبيق على مصفوفة 3×3): لو كانت $A = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix}$ و $x = (1,\ 1.4,\ 1)^\top$ فإن $Ax = (3.4,\ 4.8,\ 3.4)^\top$ والنسب: $3.4,\ 3.429,\ 3.4$ $\Longrightarrow$

$$3.400 \le \rho(A) \le 3.429$$

القيمة الحقيقية: $\lambda_k = 2 + 2\cos\frac{k\pi}{4}$ $\Longrightarrow$ $\rho = 2 + 2\cos(22.5^\circ) = 2 + 1.848 = 3.848$. **لا يقع في النطاق!** $\Longrightarrow$ خطأ: الحساب خاطئ. نراجع: Ax للعمود الأول: $2 \cdot 1 + 1 \cdot 1.4 + 0 \cdot 1 = 3.4$ ✓، الثاني: $1 + 1 \cdot 1 + 2 \cdot 1.4 + 1 \cdot 1 = 1 + 2.8 + 1 = 4.8$ ✓، الثالث: $0 + 1 \cdot 1.4 + 2 \cdot 1 = 3.4$ ✓. النسب: $3.4/1 = 3.4$، $4.8/1.4 = 3.4286$، $3.4/1 = 3.4$ $\Longrightarrow$ $\rho \in [3.4, 3.4286]$. لكن ρ الحقيقي $= 3.848$. **تناقض** $\Longrightarrow$ **خطأ في صيغة القيم الذاتية.** التصحيح: لهذه المصفوفة (ثلاثية القطر بـ $a = 2$، $b = 1$) الصيغة $\lambda_k = 2 + 2\cos\frac{k\pi}{n+1} = 2 + 2\cos\frac{k\pi}{4}$ بقيم $k = 1, 2, 3$: $k = 1$: $2 + 2(0.7071) = 3.4142$؛ $k = 2$: 2؛ $k = 3$: $2 - 1.4142 = 0.5858$. إذن $\rho = 3.4142$ وهو **داخل** النطاق $[3.4,\ 3.4286]$ ✓.

الخطوة 7 (استنتاج منهجي): كولاتس-فيلانت أداة **تحقّق وتشخيص** ممتازة: إن خرجت القيمة عن النطاق ففي الحساب خطأ.

النتيجة: $[3.818,\ 4.1]$ باختبار واحد، و $[3.4,\ 3.4286]$ للمصفوفة الثلاثية (الحقيقي 3.4142 ✓).

الربط بالذكاء الاصطناعي: هذه المتراجحة هي التي تجعل من الممكن **إصدار شهادات رياضية** على حدود النموّ في الشبكات العصبية المتكرّرة (مثلاً لإثبات أن النظام لن ينفجر) من دون حساب طيفي كامل.

مثال (4.6.3-3): بناء مصفوفة جوجل لشبكة صفحات صغيرة

المعطيات: 4 صفحات A, B, C, D بروابط: $A \to B$، $B \to C$، $C \to A$، $C \to D$، $D \to A$. معامل التخفيف $\alpha = 0.15$.

المطلوب: (أ) مصفوفة الانتقال P. (ب) مصفوفة جوجل G. (ج) تحقّق أن G عشوائية وموجبة.

الحل:

الخطوة 1 (الدرجات الخارجة): $d^{\text{out}}(A) = 1$، $d^{\text{out}}(B) = 1$، $d^{\text{out}}(C) = 2$، $d^{\text{out}}(D) = 1$.

الخطوة 2 (P عشوائية صفّياً): $P_{ij} = 1/d^{\text{out}}(i)$ إذا وُجد رابط $i \to j$:

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0.5 & 0 & 0 & 0.5 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

الخطوة 3 (التحقّق): مجاميع الصفوف: $1,\ 1,\ 1,\ 1$ ✓.

الخطوة 4 (مصفوفة الانتقال العشوائي): $\alpha \cdot \frac{1}{n}\mathbf{1}\mathbf{1}^\top = 0.15 \times 0.25 \cdot J = 0.0375\, J$ حيث J مصفوفة الواحدات.

الخطوة 5 (G بـ (41.4)): $G = 0.0375\, J + 0.85\, P$:

$$G = \begin{bmatrix} 0.0375 & 0.8875 & 0.0375 & 0.0375 \\ 0.0375 & 0.0375 & 0.8875 & 0.0375 \\ 0.4625 & 0.0375 & 0.0375 & 0.4625 \\ 0.8875 & 0.0375 & 0.0375 & 0.0375 \end{bmatrix}$$

(مثال: $G_{C,A} = 0.0375 + 0.85 \times 0.5 = 0.0375 + 0.425 = 0.4625$ ✓)

الخطوة 6 (التحقّق من كونها عشوائية): الصف الأول: $0.0375 + 0.8875 + 0.0375 + 0.0375 = 1.0$ ✓؛ الصف الثالث: $0.4625 + 0.0375 + 0.0375 + 0.4625 = 1.0$ ✓.

الخطوة 7 (التحقّق من الإيجابية القطعية): أصغر عنصر $0.0375 > 0$ ✓ $\Longrightarrow$ G موجبة قطعاً $\Longrightarrow$ **بدائية** $\Longrightarrow$ تنطبق PF $\Longrightarrow \pi > 0$ وحيد.

الخطوة 8 (لماذا نحتاج α؟) بدون التخفيف، المصفوفة P تحوي أصفاراً كثيرة وقد تكون قابلة للاختزال أو دورية $\Longrightarrow$ قد لا يوجد توزيع مستقر وحيد. التخفيف يجعل كل الصفحات متصلة $\Longrightarrow$ ضمان رياضي.

النتيجة: P و G كما أعلاه، G عشوائية صفّياً وموجبة قطعاً $\Longrightarrow$ PageRank وحيد وموجب.

الربط بالذكاء الاصطناعي: المصفوفة G تُبنى على شبكة ويب بمليارات العُقد، لكنها **متفرّقة** (كل صف فيه ≈ 10 عناصر غير صفرية من P زائد الكثيف J الذي يُعامل ضمنياً بالصيغة $\pi G = (1-\alpha)\pi P + \frac{\alpha}{n}\mathbf{1}^\top$) $\Longrightarrow$ كل تكرار يكلّف $O(|E|)$ فقط. هذه الصيغة («لا تكوّن G صريحاً») هي سرّ قابلية PageRank للتوسّع.

مثال (4.6.4-4): حساب PageRank بتكرار القوة

المعطيات: مصفوفة G من المثال السابق، والبداية $\pi^{(0)} = (0.25,\ 0.25,\ 0.25,\ 0.25)^\top$.

المطلوب: أربع تكرارات من $\pi^{(k+1)} = \pi^{(k)}G$ والتحقّق من حفظ المجموع.

الحل:

الخطوة 1 (التحديث كمتوسط مرجّح): بما أن $\pi^{(0)}$ منتظم فإن $\pi^{(1)}$ هو متوسط صفوف G (عمود بعمود):

$$\pi^{(1)}_A = \tfrac{1}{4}(0.0375 + 0.0375 + 0.4625 + 0.8875) = \tfrac{1.425}{4} = 0.35625$$

$$\pi^{(1)}_B = \tfrac{1}{4}(0.8875 + 0.0375 + 0.0375 + 0.0375) = \tfrac{1.0}{4} = 0.25$$

$$\pi_C^{(1)} = \tfrac{1}{4}(0.0375 + 0.8875 + 0.0375 + 0.0375) = 0.25$$

$$\pi_D^{(1)} = \tfrac{1}{4}(0.0375 + 0.0375 + 0.4625 + 0.0375) = \tfrac{0.575}{4} = 0.14375$$

$$\pi^{(1)} = (0.35625,\ 0.25,\ 0.25,\ 0.14375), \qquad \text{المجموع} = 1.0\ \checkmark$$

الخطوة 2 ($\pi^{(2)}$):

$$\pi_A^{(2)} = 0.35625(0.0375)+0.25(0.0375)+0.25(0.4625)+0.14375(0.8875) = 0.013359+0.009375+0.115625+$$

$$\pi_B^{(2)} = 0.35625(0.8875)+0.25(0.0375)+0.25(0.0375)+0.14375(0.0375) = 0.316172+0.009375+0.009375+$$

$$\pi_C^{(2)} = 0.35625(0.0375)+0.25(0.8875)+0.25(0.0375)+0.14375(0.0375) = 0.013359+0.221875+0.009375+$$

$$\pi_D^{(2)} = 0.35625(0.0375) + 0.25(0.0375) + 0.25(0.4625) + 0.14375(0.0375) = 0.143750$$

$$\pi^{(2)} = (0.265937,\ 0.340313,\ 0.250,\ 0.14375), \qquad \text{المجموع} = 1.0\ \checkmark$$

الخطوة 3 ($\pi^{(3)}$) — بنفس الطريقة:

$$\pi^{(3)} = (0.265938,\ 0.263547,\ 0.326767,\ 0.143751)$$

(تحقّق المجموع: $0.265938 + 0.263547 + 0.326767 + 0.143751 = 1.000003 \approx 1$ ✓)

الخطوة 4 ($\pi^{(4)}$):

$$\pi_A^{(4)} = 0.265938(0.0375) + 0.263547(0.0375) + 0.326767(0.4625) + 0.143751(0.8875)$$

$$= 0.009973 + 0.009883 + 0.151130 + 0.127579 = 0.298565$$

$$\pi_B^{(4)} = 0.265938(0.8875)+0.263547(0.0375)+0.326767(0.0375)+0.143751(0.0375) = 0.263548$$

$$\pi_C^{(4)} = 0.265938(0.0375)+0.263547(0.8875)+0.326767(0.0375)+0.143751(0.0375) = 0.261516$$

$$\pi_D^{(4)} = 0.265938(0.0375)+0.263547(0.0375)+0.326767(0.4625)+0.143751(0.0375) = 0.176377$$

$$\pi^{(4)} = (0.298565,\ 0.263548,\ 0.261516,\ 0.176377), \qquad \text{المجموع} = 1.000006 \approx 1\ \checkmark$$

الخطوة 5 (ملاحظة التذبذب): القيم تتذبذب بين التكرارات $(A : 0.356 \to 0.266 \to 0.266 \to 0.299)$ لأن الرسم شبه دوري، لكن هذا التذبذب يخمد بعامل 0.85^k.

الخطوة 6 (الترتيب الناشئ): $A > B \approx C > D$ — و A أعلى لأن الصفحتين C و D كلتاهما تشيران إليها ✓.

النتيجة: بعد 4 تكرارات: $\pi \approx (0.299,\ 0.264,\ 0.262,\ 0.176)$، الترتيب $A \succ B \approx C \succ D$.

الربط بالذكاء الاصطناعي: هذا بالضبط ما تفعله خوارزميات ترتيب العُقد (Personalized PageRank، TrustRank) في محركات البحث وأنظمة التوصية وتحليل الشبكات الاجتماعية. وصيغة «تكرار القوة على مصفوفة متفرّقة» هي نفسها صيغة تحديث التمثيلات في GNN.

مثال (4.6.5): عدد التكرارات اللازمة لتقارب PageRank

المعطيات: $\alpha = 0.15$ (قيمة جوجل الأصلية)، ومعيار التوقّف $\|\pi^{(k+1)} - \pi^{(k)}\|_1 < 10^{-6}$.

المطلوب: (أ) كم تكراراً نحتاج؟ (ب) كم لو استخدمنا $\alpha = 0.35$؟ (ج) المقايضة.

الحل:

الخطوة 1 (الحدّ النظري من (4.4.3)): $\|\pi^{(k)} - \pi\|_1 \le 2(1-\alpha)^k$؛ نطلب $2(0.85)^k \le 10^{-6}$:

$$k \;\ge\; \frac{\ln(10^{-6}/2)}{\ln 0.85} = \frac{\ln(5\times 10^{-7})}{-0.16252} = \frac{-14.5087}{-0.16252} = 89.3 \Longrightarrow k = 90 \text{ تكراراً}$$

الخطوة 2 (بمعيار 10^{-8} كما في الأنظمة الحقيقية): $k \ge \frac{\ln(5\times 10^{-9})}{-0.16252} = \frac{-19.1138}{-0.16252} = 117.6 \Longrightarrow 118$ تكراراً.

الخطوة 3 (بـ $\alpha = 0.35$): $\Longrightarrow 1-\alpha = 0.65$

$$k \ge \frac{-14.5087}{\ln 0.65} = \frac{-14.5087}{-0.43078} = 33.7 \Longrightarrow 34 \text{ تكراراً}$$

أي تسريع $\times 2.6$.

الخطوة 4 (المقايضة): رفع α يسرّع التقارب لكنه **يُفسد جودة الترتيب** لأنه يدفع التوزيع نحو المنتظم $\frac{1}{n}\mathbf{1}$:

$$\pi(\alpha) \;\longrightarrow\; \tfrac{1}{n}\mathbf{1} \quad \text{عند} \alpha \to 1$$

الخطوة 5 (قياس كمّي للتشويه): انتشار التوزيع (max − min) من المثال السابق: بـ $\alpha = 0.15$ بعد تكرار واحد $= 0.3125 - 0.1875 = 0.125$ (انظر المثال القادم) بـ $\alpha = 0.5$ $= 0.35625 - 0.14375 = 0.2125$ $\Longrightarrow$ انكماش 41% في التمييز بين الصفحات.

الخطوة 6 (الاختيار الأمثل): القيمة الشائعة $\alpha = 0.15$ توازن بين (أ) جودة الترتيب (الاعتماد على بنية الرسم) و (ب) سرعة التقارب و (ج) مقاومة «مزارع الروابط» (link farms).

الخطوة 7 (تسريع عملي): بدل رفع α نستخدم: (1) تكرارات كريلوف (GMRES/Lanczos) التي تتقارب أسرع من تكرار القوة، (2) التهيئة بتوزيع التكرار السابق (warm start) لأن الويب يتغيّر تدريجياً، (3) الحساب المتوازي على مجموعات العُقد.

النتيجة: 90 تكراراً بـ $\alpha = 0.15$ و $\varepsilon = 10^{-6}$، 34 تكراراً بـ $\alpha = 0.35$، المقايضة بين السرعة وجودة الترتيب.

الربط بالذكاء الاصطناعي: نفس المقايضة تظهر في GNN: زيادة «الانتقال العشوائي» (teleport) تسرّع الانتشار لكنها تدمج التمثيلات (oversmoothing). وفهمها عبر الطيف هو ما يجعل الضبط منهجياً لا تجريبياً.

مثال (4.6.6): مركزية المتجه الذاتي مقابل مركزية الدرجة

المعطيات: شبكة اجتماعية من 4 أشخاص بمصفوفة مجاورة (غير موجّهة):

$$A = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

المطلوب: (أ) مركزية المتجه الذاتي (بـ (4.4.4)). (ب) مركزية الدرجة. (ج) المقارنة.

الحل:

الخطوة 1 (استغلال التناظر): العقدتان 2 و 3 متماثلتان $\Longrightarrow c = (a,\ b,\ b,\ d)^\top$.

الخطوة 2: $Ac = \big(b+b+d,\ \ a+b,\ \ a+b,\ \ a\big)^\top = (2b+d,\ a+b,\ a+b,\ a)^\top = \lambda(a,\ b,\ b,\ d)^\top$.

الخطوة 3 (المعادلات): $2b + d = \lambda a$ (1)؛ $a + b = \lambda b$ (2)؛ $a = \lambda d$ (3).

الخطوة 4 (الاختزال): من (2): $a = b(\lambda - 1) \Longrightarrow b = \frac{a}{\lambda - 1}$. من (3): $d = \frac{a}{\lambda}$. نعوّض في (1):

$$\frac{2a}{\lambda - 1} + \frac{a}{\lambda} = \lambda a \implies \frac{2}{\lambda - 1} + \frac{1}{\lambda} = \lambda \implies 2\lambda + (\lambda - 1) = \lambda^2(\lambda - 1)$$

$$\lambda^3 - \lambda^2 - 3\lambda + 1 = 0$$

الخطوة 5 (الحلّ): نختبر: $\lambda = 2$: $8 - 4 - 6 + 1 = -1$؛ $\lambda = 2.2$: $10.648 - 4.84 - 6.6 + 1 = 0.208$؛ $\lambda = 2.17$: $\Longrightarrow 10.218 - 4.709 - 6.51 + 1 = -0.001$

$$\lambda_1 = 2.170 = \rho(A)$$

الخطوة 6 (المتجه): $b = \frac{a}{1.170} = 0.8547a$؛ $d = \frac{a}{2.170} = 0.4608a$. التوحيد الإقليدي: $a^2 + 2b^2 + d^2 = 1 \Longrightarrow a^2(1 + 1.4610 + 0.2123) = 2.6733a^2 = 1$:

$$a = 0.6116$$

$$c = (0.6116,\ 0.5228,\ 0.5228,\ 0.2818)^\top$$

الخطوة 7 (التحقّق): $Ac = (0.5228 + 0.5228 + 0.2818,\ 0.6116 + 0.5228,\ 0.6116 + 0.5228)^\top = (1.3274,\ 1.1344,\ 1.1344,\ 0.6116)^\top$ و $2.170\,c = (1.3272,\ 1.1345,\ 1.1345,\ 0.6115)^\top$؛ ✓.

الخطوة 8 (مركزية الدرجة): $d = (3,\ 2,\ 2,\ 1)$؛ بالتوحيد على الأكبر: $(1,\ 0.667,\ 0.667,\ 0.333)$.

الخطوة 9 (المقارنة): الترتيب متطابق: $1 \Longrightarrow 2 = 3 \succ 4$ لكن **النسب** مختلفة: $\frac{c_1}{c_4} = 2.17$ مقابل $\frac{d_1}{d_4} = 3$. مركزية المتجه الذاتي «أكثر اعتدالاً» لأنها لا تعاقب العقدة الطرفية بقدر ما تفعل مركزية الدرجة — فالعقدة 4 مرتبطة بالعقدة 1 (المهمة) وهذا يُحسب لها.

النتيجة: $c = (0.612,\ 0.523,\ 0.523,\ 0.282)$؛ $\rho = 2.170$؛ الترتيب متطابق مع مركزية الدرجة لكن النسب أقل تطرفاً.

الربط بالذكاء الاصطناعي: مركزية المتجه الذاتي تقف خلف خوارزميات ترتيب العُقد في GNN وتحليل الشبكات، وهي الصيغة الخطية التي تعمّمها «مركزية كاتز» (Katz centrality) و «العدد الثانوي للروابط». وهي أساس فكرة «التمثيلات البنيوية» (structural embeddings).

مثال (٤.٦-7): من العقدة الأكثر تأثيراً؟ ولماذا؟

المعطيات: مصفوفة جوجل من المثال 4.6-3 والترتيب النهائي $\pi \approx (A : 0.30,\ B : 0.26,\ C : 0.26,\ D : 0.18)$.

المطلوب: فسّر الترتيب بنيوياً، وتحقّق منه بمقياس «الروابط الداخلة».

الحل:

الخطوة 1 (الروابط الداخلة): A يستقبل من C و $D \Longrightarrow 2$؛ B من $A \Longrightarrow 1$؛ C من $B \Longrightarrow 1$؛ D من $C \Longrightarrow 1$.

الخطوة 2: الترتيب بالروابط الداخلة: $A \succ B = C = D \Longrightarrow A \succ B \approx C \succ D$ يعطي PageRank **متفق في القمّة** ✓ **ومختلف في الذيول.**

الخطوة 3 (لماذا $B = C = D$ وليس $B \approx C$؟) لأن C يستقبل من B **وزيادة** يمرّر نصف رتبته إلى $D \Longrightarrow C$ «محطة عبور» مهمة. في المقابل D يستقبل من C لكنه يمرّر كل رتبته إلى $A \Longrightarrow$ لا يحتفظ بشيء.

الخطوة 4 (التحليل بالمعادلة): من $\pi = (1 - \alpha)\pi P + \frac{\alpha}{n}\mathbf{1}^\top$:

$$\pi_A = 0.85\,(0.5\pi_C + 1.0\pi_D) + 0.0375$$

$$\pi_B = 0.85\,(1.0\pi_A) + 0.0375$$
$$\pi_C = 0.85\,(1.0\pi_B) + 0.0375$$
$$\pi_D = 0.85\,(0.5\pi_C) + 0.0375$$

الخطوة 5 (التحقّق بالقيم التقريبية): بـ $\pi \approx (0.30,\ 0.26,\ 0.26,\ 0.18)$: $\pi_B \approx 0.85(0.30) + 0.0375 = 0.2925$ (مقابل 0.2635 من التكرار — لم يتقارب بعد). نستمر في التكرار حتى الاستقرار.

الخطوة 6 (الاستنتاج): «الأهمية» في PageRank ليست عدد الروابط الداخلة فقط، بل **أهمية من يربط بك.** وهذا هو الفرق الجوهري عن المقاييس البسيطة، وهو ما يجعلها مقاومة للتلاعب الجزئي.

النتيجة: A الأكثر تأثيراً لأنها تستقبل من صفحتين إحداهما (C) عالية الترتيب وتمرّر رتبتها.

الربط بالذكاء الاصطناعي: نفس المنطق يُستخدم اليوم في: ترتيب النتائج في محرّكات البحث المتجهية (vector graph + search)، (reranking وتحديد «المؤثّرين» في التسويق الشبكي، واكتشاف العُقد الحرجة في شبكات الحواسيب للدفاع السيبراني.

مثال (6.4-8): أثر معامل التخفيف α على جودة الترتيب

المعطيات: نفس الرسم من المثال 6.4-3. نقارن $\alpha = 0.15$ و $\alpha = 0.5$.

المطلوب: (أ) احسب تكراراً واحداً لكلٍّ منهما. (ب) قارن «انتشار» التوزيع. (ج) أيهما تختار؟

الحل:

الخطوة 1 ($\alpha = 0.5$): $G = \frac{0.5}{4}J + 0.5P = 0.125\,J + 0.5\,P$:

$$G_{0.5} = \begin{bmatrix} 0.125 & 0.625 & 0.125 & 0.125 \\ 0.125 & 0.125 & 0.625 & 0.125 \\ 0.375 & 0.125 & 0.125 & 0.375 \\ 0.625 & 0.125 & 0.125 & 0.125 \end{bmatrix}$$

(مثال: $G_{C,A} = 0.125 + 0.5 \times 0.5 = 0.375$ ✓؛ مجاميع الصفوف $= 1$ ✓)

الخطوة 2 (تكرار واحد من التوزيع المنتظم):

$$\pi_A^{(1)} = \tfrac{1}{4}(0.125 + 0.125 + 0.375 + 0.625) = \tfrac{1.25}{4} = 0.3125$$

$$\pi_B^{(1)} = \tfrac{1}{4}(0.625{+}0.125{+}0.125{+}0.125) = 0.25, \qquad \pi_C^{(1)} = \tfrac{1}{4}(0.125{+}0.625{+}0.125{+}0.125) = 0.25$$

$$\pi_D^{(1)} = \tfrac{1}{4}(0.125 + 0.125 + 0.375 + 0.125) = \tfrac{0.75}{4} = 0.1875$$

الخطوة 3 ($\alpha = 0.15$ — من المثال 6.4-4): $\pi^{(1)} = (0.35625,\ 0.25,\ 0.25,\ 0.14375)$.

الخطوة 4 (الانتشار = max − min):

$$\alpha = 0.15:\ 0.35625 - 0.14375 = 0.2125, \qquad \alpha = 0.5:\ 0.3125 - 0.1875 = 0.125$$

الخطوة 5 (النتيجة): رفع α من 0.15 إلى 0.5 قلّص التمييز بين الصفحات بـ $41\% \Longrightarrow$ الترتيب أصبح أقرب إلى «الكل متساوٍ».

الخطوة 6 (التفسير الحدّي): عند $\alpha = 1$ يصبح $G = \frac{1}{n}J \Longrightarrow \pi = \frac{1}{n}\mathbf{1}$ (منتظم تماماً، بلا معلومة). وعند $\alpha = 0$ يصبح $G = P \Longrightarrow$ نعود إلى مشاكل الاختزال والدورية.

الخطوة 7 (الاختيار): $\alpha = 0.15$ هو توازن مجرَّب: تكفي لإيجابية G وضمان الوحودية والتقارب بـ $90 \approx$ تكراراً، مع احتفاظ الترتيب بـ 85% من بنية الرسم.

النتيجة: α أكبر $\Longrightarrow$ تقارب أسرع لكن تمييز أضعف، 0.15 هو التوازن المعتمد.

الربط بالذكاء الاصطناعي: نظير هذا المعامل في GNN هو وزن «الروابط الذاتية» (sefl-loop weight) وفي النماذج الانتشارية هو «جدول الضجيج». **في كل الحالات: مقدار الخلط مع التوزيع المنتظم يتحكّم في المقايضة بين الاستقرار والتمييز.**

مثال (4.6-9): مصفوفة قابلة للاختزال — عندما يفشل تكرار القوة

المعطيات: سلسلة صفحات «تمتصّ» الرتبة: $1 \to 2 \to 3 \to 3$ (العقدة 3 حوض absorbing).

$$P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix}$$

المطلوب: (أ) بيّن أن P قابلة للاختزال. (ب) ماذا يحدث لـ PageRank بلا تخفيف؟ (ج) كيف يحلّ التخفيف المشكلة؟

الحل:

الخطوة 1 (الاختزال): P مثلثية عليا $\Longrightarrow$ **قابلة للاختزال** (الرسم غير قوي الاتصال: لا يمكن العودة من 3 إلى 1 أو 2).

الخطوة 2 (الطيف): مثلثية $\Longrightarrow$ القيم الذاتية = عناصر القطر $(1,\ 0,\ 0) = \Longrightarrow \rho = 1$ (كما يجب لأي مصفوفة عشوائية).

الخطوة 3 (المتجه الذاتي الأيسر): نحلّ $\pi P = \pi$: $\pi_1 = 0$ (لا أحد يربط بـ 1)؛ $\pi_2 = \pi_1 \cdot 1 + 0 = 0$؛ $\Longrightarrow \pi_3 = \pi_2 + \pi_3 = \pi_3$

$$\pi = (0,\ 0,\ 1)$$

غير موجب $\Longrightarrow$ تنتهك (4.39) (التي تشترط عدم الاختزال) $\Longrightarrow$ **كل الرتبة تتركّز في العقدة 3.**

الخطوة 4 (المعنى): أي سائح عشوائي يقع في الحوض 3 ولا يخرج $\Longrightarrow$ كل «الأهمية» تذهب لصفحة واحدة $\Longrightarrow$ الترتيب بلا فائدة.

الخطوة 5 (الحل بالتخفيف): بـ $\alpha = 0.15$: $G = 0.05\,J + 0.85\,P$:

$$G = \begin{bmatrix} 0.05 & 0.90 & 0.05 \\ 0.05 & 0.05 & 0.90 \\ 0.05 & 0.05 & 0.90 \end{bmatrix}$$

الخطوة 6 (التوزيع المستقر الجديد): $\pi_2 = 0.90\pi_1 + \pi_1 = 0.05 \Longrightarrow \pi_1 = 0.05(\pi_1 + \pi_2 + \pi_3) = 0.05$
$\pi_3 = 1 - 0.05 - 0.0925 = 0.05\pi_2 + 0.05\pi_3 = 0.045 + 0.05(0.95) = 0.045 + 0.0475 = 0.0925$
0.8575

$$\pi = (0.05,\ 0.0925,\ 0.8575), \qquad \pi_i > 0\ \checkmark$$

الخطوة 7 (التحقّق): $\pi_3 = 0.05\pi_1 + 0.90\pi_2 + 0.90\pi_3 = 0.0025 + 0.08325 + 0.77175 = 0.85750$ ✓.

الخطوة 8 (الاستنتاج): التخفيف جعل G **موجبة قطعاً** $\Longrightarrow$ غير قابلة للاختزال وبدائية $\Longrightarrow$ ينطبق (4.39) $\Longrightarrow$ توزيع وحيد موجب. لاحظ أن العقدة 3 ما زالت الأعلى (0.8575) لكن بقي للعقدتين الأخريين نصيب $\Longrightarrow$ الترتيب صالح للاستخدام.

النتيجة: بلا تخفيف $\pi = (0, 0, 1)$ (انهيار)؛ بالتخفيف $\pi = (0.05,\ 0.0925,\ 0.8575)$ ✓.
الربط بالذكاء الاصطناعي: هذه الظاهرة تظهر في GNN على الرسوم ذات «المكوّنات المغلقة» وفي التعلّم المعزّز عندما تكون بعض الحالات نهائية (terminal states) $\Longrightarrow$ تُحَلّ بإعادة التشغيل العشوائي (ε-restarts) تماماً كما هنا.

مثال (6.4-10): العقد المعلّقة (dangling nodes) وتسريب الكتلة

المعطيات: نعدّل مثال 6.4-3 فنجعل الصفحة D بلا روابط خارجة (dangling).
المطلوب: (أ) بيّن مشكلة المصفوفة G. (ب) احسب الكتلة المفقودة في تكرار واحد. (ج) العلاج.
الحل:
الخطوة 1: صف D في P يصبح أصفاراً $\Longrightarrow$ صف D في G:

$$G_{D,:} = \frac{\alpha}{n}\mathbf{1}^\top + (1-\alpha)\cdot \mathbf{0}^\top = (0.0375,\ 0.0375,\ 0.0375,\ 0.0375)$$

مجموعه $1 \neq 0.15 = G \Longrightarrow$ **تحت-عشوائية** (sub-stochastic) $\Longrightarrow$ الكتلة تتسرّب.
الخطوة 2 (الكاملة):

$$G = \begin{bmatrix} 0.0375 & 0.8875 & 0.0375 & 0.0375 \\ 0.0375 & 0.0375 & 0.8875 & 0.0375 \\ 0.4625 & 0.0375 & 0.0375 & 0.4625 \\ 0.0375 & 0.0375 & 0.0375 & 0.0375 \end{bmatrix}$$

الخطوة 3 (تكرار واحد من المنتظم):

$$\pi_A^{(1)} = \tfrac{1}{4}(0.0375 + 0.0375 + 0.4625 + 0.0375) = \tfrac{0.575}{4} = 0.14375$$
$$\pi_B^{(1)} = \tfrac{1}{4}(0.8875 + 0.0375 + 0.0375 + 0.0375) = 0.25$$
$$\pi_C^{(1)} = \tfrac{1}{4}(0.0375 + 0.8875 + 0.0375 + 0.0375) = 0.25$$
$$\pi_D^{(1)} = \tfrac{1}{4}(0.0375 + 0.0375 + 0.4625 + 0.0375) = 0.14375$$

$$\text{المجموع} = 0.14375 + 0.25 + 0.25 + 0.14375 = 0.7875$$

الخطوة 4 (الكتلة المفقودة): $1 - 0.7875 = 0.2125$ أي 21.25%. وتفسيرها الدقيق: الكتلة التي كانت على D هي 0.25، و D «ينتقل عشوائياً» بنسبة $\alpha = 0.15$ فقط فيفقد $0.25 \times 0.85 = 0.25 \times (1 - 0.15) = 0.2125$ ✓ تطابق تام.
الخطوة 5 (الخطر): مع التكرار تتسرّب كل الكتلة $\Longrightarrow \pi^{(k)} \to 0 \Longrightarrow$ الخوارزمية تفشل تماماً.
الخطوة 6 (العلاج القياسي): استبدال صفوف العقد المعلّقة بالتوزيع المنتظم $\frac{1}{n}\mathbf{1}^\top$ (تفسير: السائح «ينتقل عشوائياً» حتماً إذا لم يجد رابطاً):

$$P_{D,:} \longleftarrow (0.25,\ 0.25,\ 0.25,\ 0.25)$$

$$G_{D,:} = 0.0375\,J + 0.85 \times 0.25\,J = (0.0375 + 0.2125)\,J = 0.25\,J \quad \text{مجموعه } 1 \checkmark$$

الخطوة 7 (بدائل أخرى): (أ) حذف العقد المعلّقة (تكرارياً حتى الاستقرار)؛ (ب) توجيهها إلى «عقدة صندوق» (sink node) تُعامل كعقدة معلّقة بدورها؛ (ج) استخدام $\alpha = 1$ على صفوفها فقط.

الخطوة 8 (التحقّق بعد العلاج): مجاميع كل صفوف G = 1 $\Longrightarrow$ التكرار يحفظ الكتلة $\Longrightarrow$ التقارب مضمون بـ (42.4).

النتيجة: الكتلة المفقودة 21.25% = في تكرار واحد، العلاج باستبدال صفوف العقد المعلّقة بالمنتظم $\Longrightarrow$ G عشوائية تماماً.

الربط بالذكاء الاصطناعي: نظير هذه المشكلة في GNN هو العُقد المعزولة (isolated nodes) التي تُسبّب أصفاراً في القطر وتفشل تطبيع $D^{-1/2}$ $\Longrightarrow$ العلاج المعتاد إضافة روابط ذاتية (sefl-loops) وهو تماماً نظير «الانتقال العشوائي».

مثال (11-6.4): ترتيب العناصر في نظام توصية بسير عشوائي على رسم العناصر

المعطيات: 3 عناصر وتفاعلات: $u_1 : \{i_1, i_2\}$، $u_2 : \{i_1, i_2, i_3\}$، $u_3 : \{i_1\}$.

المطلوب: (أ) ابنِ رسم العناصر من التلازم. (ب) احسب التوزيع المستقر. (ج) أوصِ لمستخدم استهلك i_1.

الحل:

الخطوة 1 (مصفوفة التلازم): عدد المستخدمين الذين تفاعلوا مع الزوج:

$$w_{12} = |\{u_1, u_2\}| = 2, \qquad w_{13} = |\{u_2\}| = 1, \qquad w_{23} = |\{u_2\}| = 1$$

$$W = \begin{bmatrix} 0 & 2 & 1 \\ 2 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

الخطوة 2 (مصفوفة الانتقال): بتطبيع الصفوف (الدرجات 2 ,3 ,3):

$$P = \begin{bmatrix} 0 & 2/3 & 1/3 \\ 2/3 & 0 & 1/3 \\ 1/2 & 1/2 & 0 \end{bmatrix}$$

الخطوة 3 (التوزيع المستقر): نحلّ $\pi = \pi P$. بالتناظر بين 1 و 2: $\pi_1 = \pi_2$: $\pi_1 = \frac{2}{3}\pi_2 + \frac{1}{2}\pi_3 = \frac{2}{3}\pi_1 + \frac{1}{2}\pi_3$ $\Longrightarrow$ $\frac{1}{3}\pi_1 = \frac{1}{2}\pi_3$ $\Longrightarrow$ $\pi_1 = \frac{3}{2}\pi_3$ $\pi_3 = \frac{1}{3}\pi_1 + \frac{1}{3}\pi_2 = \frac{2}{3}\pi_1$ ✓ متسق (لأن $\pi_1 = 1.5\pi_3 \Longleftrightarrow \pi_3 = \frac{2}{3}\pi_1$) التوحيد: $1 = \pi_1 + \pi_2 + \pi_3 = 2\pi_1 + \frac{2}{3}\pi_1 = \frac{8}{3}\pi_1$ $\Longrightarrow$ $\pi_1 = \frac{3}{8} = 0.375$:

$$\pi = (0.375,\ 0.375,\ 0.250)$$

الخطوة 4 (التخصيص الشخصي — PageRank Personalized من i_1): بـ $\alpha = 0.15$: $G = 0.05\, J + 0.85\, P$:

$$\text{صف} i_1 = (0.05,\ 0.05 + 0.85 \cdot \tfrac{2}{3},\ 0.05 + 0.85 \cdot \tfrac{1}{3}) = (0.05,\ 0.6167,\ 0.3333)$$

$$\text{صف} i_2 = (0.6167,\ 0.05,\ 0.3333), \qquad \text{صف} i_3 = (0.475,\ 0.475,\ 0.05)$$

من $\pi^{(0)} = (1, 0, 0)$: $\pi^{(1)} = (0.05,\ 0.6167,\ 0.3333)$؛ ثم:

$$\pi_1^{(2)} = 0.05(0.05) + 0.6167(0.6167) + 0.3333(0.475) = 0.0025 + 0.3803 + 0.1583 = 0.5411$$

$$\pi_2^{(2)} = 0.05(0.6167) + 0.6167(0.05) + 0.3333(0.475) = 0.0308 + 0.0308 + 0.1583 = 0.2199$$

$$\pi_3^{(2)} = 0.05(0.3333) + 0.6167(0.3333) + 0.3333(0.05) = 0.0167 + 0.2056 + 0.0167 = 0.2390$$

الخطوة 5 (التوصية): للمستخدم الذي استهلك i_1: نرتب العناصر المتبقية بالدرجة الشخصية: $i_3\ (0.239) > i_2\ (0.220)$ عند التكرار الثاني؛ ومع التقارب إلى التوزيع المستقر يصبح $i_3\ (0.250) < i_2\ (0.375)$.

الخطوة 6 (القرار): التوصية المستقرّة: i_2 (أعلى درجة بعد استبعاد المستهلَك). والدرجة «الشخصية» قصيرة المدى تعطي انطباعاً مختلفاً $\Longrightarrow$ تُستخدم عادةً بعد 5–10 تكرارات لتوازن الخصوصية والعمومية.

الخطوة 7 (الميزة على التصفية التعاونية البسيطة): السير العشوائي يلتقط علاقات **غير مباشرة**: $i_1 \to i_2 \to i_3$ يكشف عناصر لم تظهر معاً قط.

النتيجة: رسم العناصر W؛ التوزيع المستقر $(0.375,\ 0.375,\ 0.25)$؛ التوصية i_2.

الربط بالذكاء الاصطناعي: هذه هي خوارزمية **PageRank Personalized / ItemRank** التي تستخدمها أنظمة التوصية الصناعية (وخوارزمية Pixie في Pinterest على مئات الملايين من العُقد). والصيغة الحديثة تغلّفها شبكات عصبية بيانية، GraphSAGE) .(PinSage

مثال (12-6.4): خوارزمية HITS — المراكز والسلطات

المعطيات: رسم موجّه بـ 3 عُقد: $2 \to 1$، $3 \to 1$، $3 \to 2$، $1 \to 3$.

$$A = \begin{bmatrix} 0 & 1 & 1 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

المطلوب: (أ) درجات المراكز (hubs). (ب) درجات السلطات (authorities). (ج) التفسير.

الحل:

الخطوة 1 (العلاقة بـ (44.4)): $h = Aa$ و $a = A^\top h \Longrightarrow h = AA^\top h$ و $a = A^\top A\, a \Longrightarrow$ كلٌّ منهما متجه ذاتي لمصفوفة متماثلة نصف موجبة $\Longrightarrow$ تنطبق PF (بعد التأكد من عدم الاختزال).

الخطوة 2 ($AA^\top$):

$$AA^\top = \begin{bmatrix} 0+1+1 & 0+0+1 & 0+0+0 \\ 0+0+1 & 0+0+1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

الخطوة 3 (القيم الذاتية): الكتلة $\begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$: الأثر 3، المحدّد $2-1=1 \Longrightarrow \lambda^2-3\lambda+1=0 \Longrightarrow \lambda = \frac{3\pm\sqrt{5}}{2} = 2.618,\ 0.382$. والعنصر المنفصل $(3,3)$ يعطي 1. القيمة المهيمنة:

$$\lambda_1(AA^\top) = 2.618$$

الخطوة 4 (متجه المراكز): $(2-2.618)v_1 + v_2 = 0 \Longrightarrow v_2 = 0.618\, v_1$، والثالث 0:

$$h \propto (1,\ 0.618,\ 0) \xrightarrow{\text{توحيد}} h = (0.8507,\ 0.5257,\ 0)^\top$$

الخطوة 5 ($A^\top A$):

$$A^\top A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

(الأعمدة: $c_1 = (0,0,1)^\top$، $c_2 = (1,0,0)^\top$، $c_2^\top c_3 = 1 \Longrightarrow c_3 = (1,1,0)^\top$، ✓ $c_3^\top c_3 = 2$)

الخطوة 6 (متجه السلطات): الكتلة السفلية $\begin{bmatrix}1 & 1\\ 1 & 2\end{bmatrix}$ لها نفس القيم $(2.618,\ 0.382)$؛ $(1-2.618)v_2+v_3=0 \Rightarrow v_3 = 1.618\,v_2$:

$$a = (0,\ 0.5257,\ 0.8507)^\top$$

الخطوة 7 (التحقّق): $A^\top h = \begin{bmatrix}0&0&1\\1&0&0\\1&1&0\end{bmatrix}\begin{bmatrix}0.8507\\0.5257\\0\end{bmatrix} = \begin{bmatrix}0\\0.8507\\1.3764\end{bmatrix}$؛ ولو قسّمنا على $\sqrt{\lambda_1}=\sqrt{2.618}=1.618$: $a = (0,\ 0.5257,\ 0.8507)^\top$ ✓.

الخطوة 8 (التفسير): العقدة 1 أفضل **مركز** (hub) لأنها تربط بـ 2 و 3، والعقدة 3 أفضل **سلطة** (authority) لأنها تستقبل من 1 و 2. والعقدة 2 وسط بينهما.

النتيجة: $h=(0.851,\ 0.526,\ 0)$؛ $a=(0,\ 0.526,\ 0.851)$؛ $\lambda_1 = 2.618$.

الربط بالذكاء الاصطناعي: Kleinberg HITS) 1999) سبقت PageRank وتُستخدم حتى اليوم في تحليل الويب والاستشهادات الأكاديمية. وصيغتها الحديثة (القيم الذاتية لـ $A^\top A$ و $AA^\top$) هي نفسها **SVD** للمصفوفة A — فـ h_i و a_i هما المتجهات المفردة اليسرى واليمنى! (راجع (17.4)).

مثال (13-6.4): سلسلة ماركوف — التوزيع المستقر وزمن الاختلاط

المعطيات: سلسلة ماركوف بحالتين (مثلاً «نشط/خامل» لمستخدم في تطبيق):

$$P = \begin{bmatrix}0.9 & 0.1\\ 0.2 & 0.8\end{bmatrix}$$

المطلوب: (أ) التوزيع المستقر. (ب) زمن الاختلاط بدقة 1%. (ج) تحقّق.

الحل:

الخطوة 1: نحلّ $\pi P = \pi$ مع $\pi_1+\pi_2=1$:

$$\pi_1 = 0.9\pi_1 + 0.2\pi_2 \implies 0.1\pi_1 = 0.2\pi_2 \implies \pi_1 = 2\pi_2$$

$$\pi = \left(\tfrac{2}{3},\ \tfrac{1}{3}\right) = (0.6667,\ 0.3333)$$

الخطوة 2 (القيم الذاتية): الأثر $=1.7$؛ المحدّد $=0.72-0.02=0.70 \Rightarrow \lambda_1=1$ (دائماً للمصفوفة العشوائية) و $\lambda_2 = 0.7$.

الخطوة 3 (فجوة الطيف): $1-|\lambda_2| = 0.3 \Rightarrow$ معدّل التقارب $=0.7^k$.

الخطوة 4 (زمن الاختلاط): نطلب $0.7^k \le 0.01$:

$$k \ge \frac{\ln 0.01}{\ln 0.7} = \frac{-4.6052}{-0.35667} = 12.91 \Rightarrow k = 13 \text{ خطوة}$$

الخطوة 5 (التحقّق العددي): من $\pi^{(0)}=(1,\ 0)$: نحسب تكرارياً — P^{13}: $\pi^{(1)}=(0.9,\ 0.1)$؛ $\pi^{(2)}=(0.9\cdot$؛ $\pi^{(3)} = (0.83\cdot 0.9+0.17\cdot 0.2,\ 0.83\cdot 0.1+0.9+0.1\cdot 0.2,\ 0.9\cdot 0.1+0.1\cdot 0.8) = (0.83,\ 0.17)$؛ $(0.17\cdot 0.8) = (0.747+0.034,\ 0.083+0.136) = (0.781,\ 0.219)$؛ الخطأ $|\pi_1^{(3)}-0.6667| = 0.1143$؛ والتنبؤ $0.7^3 = 0.343$ من خطأ ابتدائي $0.3333 \Rightarrow 0.3333\times 0.343 = 0.1143$ ✓ **تطابق تام.** وبـ $k=13$: $0.3333\times 0.7^{13} = 0.3333\times 0.00969 = 0.00323 < 0.01$ ✓.

الخطوة 6 (التفسير): بعد $13\approx$ خطوة ينسى النظام حالته الابتدائية $\Rightarrow$ أي توقّع طويل الأمد يعتمد على π فقط.

الخطوة 7 (العلاقة بـ PageRank): PageRank حالة خاصة: α يضمن $|\lambda_2| \le 1-\alpha \implies$ زمن اختلاط $\approx \frac{\ln \varepsilon}{\ln(1-\alpha)}$ — وهو بالضبط المثال 6.4-5.

النتيجة: $\pi = (2/3,\ 1/3)$، $|\lambda_2| = 0.7$؛ زمن الاختلاط $= 13$ خطوة.

الربط بالذكاء الاصطناعي: كل نموذج تسلسلي (HMM، سلاسل ماركوف، عمليات اتخاذ القرار الماركوفية MDP في التعلّم المعزّز) يعتمد على هذا التحليل: $|\lambda_2|$ يحدّد «ذاكرة» النظام ومدى اعتماده على الحالة الابتدائية. وفي RL، الفجوة الطيفية تحدّد سرعة تقييم السياسات.

مثال (6.4-14): كشف «مزرعة روابط» طيفياً

المعطيات: رسم من 4 صفحات: $\{1,2\}$ دورة مغلقة و $\{3,4\}$ دورة مغلقة، ولا روابط بينهما (هذه بنية «مزرعة روابط» كلاسيكية):

$$P = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

المطلوب: (أ) الطيف وماذا يدلّ؟ (ب) التوزيعات المستقرة. (ج) كيف نكشف المزرعة؟

الحل:

الخطوة 1 (البنية): P قطرية الكتل $\implies$ **قابلة للاختزال** $\implies$ تنتهك شروط (39.4).

الخطوة 2 (الطيف): طيف كل كتلة $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ هو $\{1,\ -1\} \implies$

$$\lambda(P) = (1,\ 1,\ -1,\ -1)$$

الخطوة 3 (التشخيص): تكرار القيمة الذاتية 1 مرّتين $\implies$ **مكوّنان مغلقان** $\implies$ كل منهما «يحتفظ» برتبته ولا يتقاسمها مع الآخر $\implies$ علامة تلاعب.

الخطوة 4 (التوزيعات المستقرة): فضاء المتجهات الذاتية اليسرى لـ 1 $=$ λ بُعده 2 $\implies$ أي مزيج $t(\frac{1}{2},\frac{1}{2},0,0) + (1-t)(0,0,\frac{1}{2},\frac{1}{2})$ $=$ π توزيع مستقر $\implies$ **غير وحيد** $\implies$ PageRank بلا تخفيف غير صالح.

الخطوة 5 (الحل بالتخفيف): بـ $\alpha = 0.15$: $G = 0.0375\,J + 0.85\,P$:

$$G = \begin{bmatrix} 0.0375 & 0.8875 & 0.0375 & 0.0375 \\ 0.8875 & 0.0375 & 0.0375 & 0.0375 \\ 0.0375 & 0.0375 & 0.0375 & 0.8875 \\ 0.0375 & 0.0375 & 0.8875 & 0.0375 \end{bmatrix}$$

موجبة قطعاً $\implies$ وحيدة، وبالتناظر $\pi = (\frac{1}{4},\frac{1}{4},\frac{1}{4},\frac{1}{4})$ المنتظم $\implies$ **لا تمييز** $\implies$ المزرعة لم تستفد.

الخطوة 6 (كيف نكشفها؟) ثلاث علامات طيفية:

١. **تكرار القيمة الذاتية 1** في P (أو في مصفوفة المجاورة المطبَّعة) $\implies$ مكوّنات مغلقة.

٢. **الفجوة الطيفية شبه معدومة** بين λ_1 و $\lambda_2 \implies$ المتجه الذاتي الثاني «متمركز» على مجموعة صغيرة $\implies$ هذا هو كاشف العناقيد/المزارع.

٣. **الموصلية (conductance) شبه صفرية** لمجموعة العُقد $\implies$ العلاج: حساب «الموصلية الطيفية» لكل عنقود مرشّح ورفض العناقيد ذات الموصلية $< \varepsilon$.

الخطوة 7 (القياس الكمّي): لو كانت المزرعة متصلة بالويب الخارجي برابط واحد فقط، فإن $\varepsilon \approx 1 - \lambda_2$ مع $\varepsilon \propto$ وزن الرابط الخارجي $\Longrightarrow$ كلما صغر الرابط الخارجي اقترب λ_2 من 1 $\Longrightarrow$ كشف مباشر.

النتيجة: $\lambda(P) = (1, 1, -1, -1)$ $\Longrightarrow$ مكوّنان مغلقان $\Longrightarrow$ توزيع غير وحيد $\Longrightarrow$ علامة تلاعب؛ التخفيف يجعل الحلّ وحيداً منتظماً.

الربط بالذكاء الاصطناعي: هذا هو الأساس الطيفي لكشف الاحتيال (fraud detection) والروابط المزيفة ومزارع المتابعين: **المجتمعات المغلقة طيفياً علامة خطر.** والطريقة الحديثة تعمّمها عبر «الموصلية الطيفية» و «الطيف المحلي» (local spectral methods).

مثال (15-6.4): ترتيب الأوراق البحثية في شبكة اقتباسات

المعطيات: 5 أوراق، الاقتباسات: $P_1 \to \{P_2, P_3\}$، $P_2 \to \{P_3\}$، $P_3 \to \{P_5\}$، $P_4 \to \{P_3\}$، P_5 لا تستشهد شيئاً (عقدة معلّقة). $\alpha = 0.15$.

المطلوب: (أ) مصفوفة الانتقال بعد معالجة العقدة المعلّقة. (ب) تكراران من PageRank. (ج) الترتيب.

الحل:

الخطوة 1 (الدرجات الخارجة): $P_5 \Longrightarrow 2,\ 1,\ 1,\ 1,\ 0$ معلّقة.

الخطوة 2 (المعالجة): صف $P_5 \longleftarrow$ منتظم $(0.2,\ 0.2,\ 0.2,\ 0.2,\ 0.2)$.

الخطوة 3 (P): $P_{1,:} = (0,\ 0.5,\ 0.5,\ 0,\ 0)$؛ $P_{2,:} = (0, 0, 1, 0, 0)$؛ $P_{3,:} = (0, 0, 0, 0, 1)$؛ $P_{4,:} = (0, 0, 1, 0, 0)$؛ $P_{5,:} = 0.2\,J$.

الخطوة 4 ($G = 0.03\,J + 0.85\,P$):

$$G = \begin{bmatrix} 0.03 & 0.455 & 0.455 & 0.03 & 0.03 \\ 0.03 & 0.03 & 0.88 & 0.03 & 0.03 \\ 0.03 & 0.03 & 0.03 & 0.03 & 0.88 \\ 0.03 & 0.03 & 0.88 & 0.03 & 0.03 \\ 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \end{bmatrix}$$

(الصف الخامس: $0.03 + 0.85 \times 0.2 = 0.2$ ✓ ومجموعه 1 ✓)

الخطوة 5 (تكرار أول من المنتظم — متوسط الأعمدة):

$$\pi^{(1)} = \big(0.064,\ 0.149,\ 0.489,\ 0.064,\ 0.234\big)$$

(تحقّق العمود الثالث: $\frac{1}{5}(0.455 + 0.88 + 0.03 + 0.88 + 0.2) = \frac{2.445}{5} = 0.489$ ✓؛ المجموع $= 1.0$ ✓)

الخطوة 6 (تكرار ثانٍ):

$$\pi_1^{(2)} = 0.064(0.03)+0.149(0.03)+0.489(0.03)+0.064(0.03)+0.234(0.2) = 0.00192+0.00447+0.01467+0.0$$

$$\pi_2^{(2)} = 0.064(0.455)+0.149(0.03)+0.489(0.03)+0.064(0.03)+0.234(0.2) = 0.02912+0.00447+0.01467+0.$$

$$\pi_3^{(2)} = 0.064(0.455)+0.149(0.88)+0.489(0.03)+0.064(0.88)+0.234(0.2) = 0.02912+0.13112+0.01467+0.$$

$$\pi_4^{(2)} = 0.06978 \text{ (بالتماثل مع 1)}, \qquad \pi_5^{(2)} = 0.064(0.03)+0.149(0.03)+0.489(0.88)+0.064(0.03)+0.234(0.2) =$$

$$\pi^{(2)} = (0.0698,\ 0.0970,\ 0.2780,\ 0.0698,\ 0.4854), \quad \text{المجموع} = 1.0\ \checkmark$$

الخطوة 7 (الترتيب): $P_5 \succ P_3 \succ P_2 \succ P_1 = P_4$.

الخطوة 8 (التفسير النقدي): P_5 في القمّة لأنها تستقبل من P_3 ولا تمرّر رتبتها لأحد (بسبب معالجة العقدة المعلّقة) $\Longrightarrow$ هذا **أثر اصطناعي** لمعالجة العقد المعلّقة. العلاجات: (أ) حذف العقد المعلّقة قبل الحساب؛ (ب) استخدام معامل تخفيف أعلى؛ (ج) وزن الاقتباسات بعمر الورقة (time-decayed PageRank) لأن الأوراق الحديثة لم تتح لها فرصة الاستشهاد.

النتيجة: $\pi^{(2)} = (0.070,\ 0.097,\ 0.278,\ 0.070,\ 0.485)$؛ الترتيب $P_5 \succ P_3 \succ P_2 \succ P_1 = P_4$، مع تحذير من الأثر الاصطناعي.

الربط بالذكاء الاصطناعي: ترتيب الأوراق العلمية (وبراءات الاختراع والمحاكم القضائية) يعتمد على هذه التقنية مع تحسينات زمنية. والدرس المنهجي المهم: **كل «إصلاح» رياضي (مثل معالجة العقد المعلّقة) يُدخل تحيّزاً يجب تقييمه** — وهذا درس عام في هندسة الخوارزميات.

6.6.4 أخطاء شائعة في بيرون–فروبينيوس و PageRank

#	الخطأ الشائع	لماذا هو خطأ	الصواب
1	افتراض أن المتجه الذاتي المهيمن موجب لأي مصفوفة	يشترط عدم السلبية وعدم الاختزال	تحقّق من شروط (39.4)
2	الخلط بين المتجه الذاتي الأيمن والأيسر	في PageRank المطلوب هو الأيسر ($\pi G = \pi$)	P عشوائية صفّياً $\Longrightarrow$ π أيسر
3	ترك العقد المعلّقة بصفوف أصفار	الكتلة تتسرّب $\pi \to 0 \Longrightarrow$	استبدل صفوفها بالمنتظم (المثال 6.4-10)
4	الاعتقاد أن $\rho(A) \le \max_i \sum_j A_{ij}$ دائماً	صحيح فقط لـ $A \ge 0$	للمصفوفات غير السالبة: نعم (نورم اللانهاية)
5	استخدام $\alpha = 0$ لتوفير الحساب	قد تفشل الوحودية والتقارب	احتفظ بـ $\alpha \ge 0.05$
6	توقّع تقارب أسرع من $(1-\alpha)^k$	هذا هو الحدّ الأقصى المضمون	$\lvert\lambda_2\rvert \le 1-\alpha$ (42.4)، وقد يكون أفضل
7	تطبيع A صفّياً عندما الروابط «واردة»	الاتجاه يحدّد نوع التطبيع	π أيسر $\Longrightarrow$ صفوف، c أيمن $\Longrightarrow$ أعمدة
8	تفسير $\lvert\lambda_2\rvert$ الكبير على أنه جيد دائماً	كبير $\Longrightarrow$ بطء التقارب وضعف الاتصال	في الترتيب نريد صغيراً، في التوسّع نريد كبيراً
9	تجاهل أن G كثيفة (بسبب J)	تخزينها $O(n^2)$	استخدم $\pi G = (1-\alpha)\pi P + \frac{\alpha}{n}\mathbf{1}^\top$ ضمنياً
10	الخلط بين PageRank ومركزية المتجه الذاتي	الأولى بمعامل تخفيف والأخرى بدونه	PageRank = مركزية مُخفَّفة (damped)

المجموعة أ — التحليل الطيفي ودوال المصفوفات (1–6)

تمرين 1. احسب القيم والمتجهات الذاتية لـ $A = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}$ وتحقّق من (4.4).

تمرين 2. ليكن $A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$. بيّن أنها غير قابلة للقطرنة وعلّق على ذلك.

تمرين 3. احسب A^5 لـ $A = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ بطريقتين: القطرنة، وكايلي–هاملتون.

تمرين 4. احسب e^{At} ثم حلّ $\dot{x} = Ax$ مع $x(0) = (1, 0)^\top$ حيث $A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$.

تمرين 5. احسب $\Sigma^{1/2}$ و $\Sigma^{-1/2}$ لـ $\Sigma = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ وتحقّق أن $(\Sigma^{1/2})^2 = \Sigma$.

تمرين 6. بيّن أن كل مصفوفة متماثلة موجبة التحديد لها جذر تربيعي متماثل موجب التحديد وحيد.

إجابات مختصرة (أ): (1) $\lambda = 6, 2$؛ $q_1 = \frac{1}{\sqrt{2}}(1,1)^\top$، $q_2 = \frac{1}{\sqrt{2}}(1,-1)^\top$. (2) $\lambda = 1$ بتكرار جبري 2 وهندسي 1 $\Longrightarrow$ defective. (3) $A^5 = \frac{1}{2}\begin{bmatrix} 3^5+(-1)^5 & 3^5-(-1)^5 \\ 3^5-(-1)^5 & 3^5+(-1)^5 \end{bmatrix} = \begin{bmatrix} 121 & 122 \\ 122 & 121 \end{bmatrix}$. (4) $x(t) = (\cosh t,\ \sinh t)^\top$. (5) $\Sigma^{1/2} = \frac{1}{\sqrt{2}}\begin{bmatrix} \sqrt{3}+1 & \sqrt{3}-1 \\ \sqrt{3}-1 & \sqrt{3}+1 \end{bmatrix} \cdot \frac{1}{2}$. (6) $Q = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$. الدقّة: $\Sigma^{1/2} = Q\,\mathrm{diag}(\sqrt{3}, 1)Q^\top$ ... $f(\lambda) = \sqrt{\lambda}$ بـ (11.4) من

والوحودية من بساطة التحليل الطيفي عند تكرار القيم الذاتية المتساوي.

المجموعة ب — SVD والتقريب من رتبة منخفضة (7–12)

تمرين 7. احسب SVD الكامل لـ $A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ (غير متماثلة!).

تمرين 8. احسب أفضل تقريب برتبة 1 لـ $A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$ والخطأ بالنورمين.

تمرين 9. بيّن أن $\|A\|_2 = \sigma_1$ و $\|A\|_F^2 = \sum \sigma_i^2$ بالاعتماد على (18.4).

تمرين 10. احسب المعكوس الشمولي $A^\dagger$ لـ $A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$ (شاذّة!) وتحقّق من شروط مور–بنروز.

تمرين 11. مصفوفة 50×50 بقيم مفردة $\sigma_i = 100/i$. كم الرتبة اللازمة لـ 99% من الطاقة؟ (استخدم تقريباً تكاملياً.)

تمرين 12. بيّن أن $\operatorname{rank}(A) = \operatorname{rank}(A^\top A)$ مستخدماً $\ker(A^\top A) = \ker(A)$.

إجابات مختصرة (ب): (7) $\sigma = (\frac{1+\sqrt{5}}{2}, \frac{\sqrt{5}-1}{2}) \approx (1.618,\ 0.618)$، $U \neq V$. (8) $A_1 = 2\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$؛ الخطأ الطيفي $= \sigma_2 = 2$ والفروبينيوس $= 2$. (10) $A^\dagger = \frac{1}{25}\begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$. (11) $\sum_i \sigma_i^2 = 10^4 \sum i^{-2} \approx 10^4 \cdot \frac{\pi^2}{6} = 16449$؛ الذيول $\sum_{i>k} \frac{10^4}{i^2} \approx \frac{10^4}{k}$ $\Longrightarrow$ نطلب $\frac{10^4/k}{16449} \leq 0.01 \Longrightarrow k \geq 61 \Longrightarrow k \approx 61$ (أو نحتفظ بكل الرتبة لأن k قريب من 50 $\Longrightarrow$ عملياً $k \approx 50$). (12) مباشرة من البرهان في §4.3.4.

المجموعة ج — رايلي وفايل والتداخل (13–18)

تمرين 13. احسب خارج قسمة رايلي لـ $A = \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix}$ عند $x = (1, 2)^\top$ وقارن بالقيم الذاتية.

تمرين 14. ليكن E بـ $\|E\|_2 = 0.1$. احسب حدّ فايل لانزياح القيم الذاتية وقارن بهوفمان–فيلانت إذا كان $\|E\|_F = 0.22$ و $n = 4$.

تمرين 15. استخدم كوران–فيشر لبيان أن $\lambda_2(A) \leq \lambda_2(B)$ إذا كان $B - A \succeq 0$.

تمرين 16. مصفوفة A بطيف $(7,\ 5,\ 1)$. احسب الفجوة الطيفية وحدّ ديفيس–كاهان على المتجه الذاتي الأول إذا $\|E\|_2 = 0.5$.

تمرين 17. تحقّق من التداخل (29.4) لحذف الصف/العمود الثالث من $A = \begin{bmatrix} 3 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 3 \end{bmatrix}$.

تمرين 18. بيّن أن $\lambda_{\max}(A+B) \leq \lambda_{\max}(A) + \lambda_{\max}(B)$ للمصفوفات المتماثلة.

إجابات مختصرة (ج): (13) $R = \frac{4\cdot1+2\cdot1\cdot2+2\cdot4}{5} = \frac{16}{5} = 3.2$؛ القيم الذاتية $\approx 4.414,\ 1.586$ $\Longrightarrow 1.586 \leq 3.2 \leq 4.414$ ✓. (14) فايل: 0.1 لكل قيمة؛ هوفمان: $\|\Delta\lambda\|_2 \leq 0.22$. (15) من (26.4): $R_A(x) \leq R_B(x)$ لكل x $\Longrightarrow$ min-max يتحقق. (16) $\sin\theta \leq 0.25 \Longrightarrow \delta = 2$ $\Longrightarrow \theta \leq 14.5°$. (17) $\lambda(A) \approx (4.414,\ 3,\ 1.586)$؛ $\lambda(B) = (4,\ 2)$ $\Longrightarrow 4.414 \geq 4 \geq 3 \geq 2 \geq 1.586$ ✓. (18) من (25.4): $R_{A+B}(x) = R_A(x) + R_B(x) \leq \lambda_{\max}(A) + \lambda_{\max}(B)$.

المجموعة د — طيف الرسم (19–24)

تمرين 19. احسب L وطيفه لرسم «مربع» C_4 وتحقّق أن $\lambda_{\max}(L_{\text{sym}}) = 2$.

تمرين 20. احسب متجه فيدلر لرسم المسار P_5 وحدّد التقسيم الناتج.

تمرين 21. بيّن أن $\lambda_2 = 0$ إذا وفقط إذا كان الرسم غير متصل.

تمرين 22. احسب ثابت شيغير لرسم الدورة C_6 وتحقّق من (36.4).

تمرين 23. احسب طيف الرسم الكامل K_4 غير المطبَّع والمطبَّع.

تمرين 24. صف مرشّحاً طيفياً يُبقي الترددات المتوسطة ويُزيل المنخفضة والعالية (band-pass) بصيغة كثيرات حدود في L.

إجابات مختصرة (د): (19) $\lambda(L) = (0, 2, 2, 4)$؛ $\lambda(L_{\text{sym}}) = (0, 1, 2, 1)$. ✓ (20) $v_1(i) = \cos\frac{\pi(i-0.5)}{5}$ $\Longrightarrow$ $f \approx (0.601,\ 0.372,\ 0,\ -0.372,\ -0.601)$ $\Longrightarrow$ التقسيم $\{1,2\} \mid \{4,5\}$ والعقدة 3 عند الصفر تُضاف للأقرب. (21) من (33.4): $\text{mult}(0) \geq 2$ $\Longleftrightarrow$ غير متصل. (22) لأي S متصل من k عُقد: $|\partial S| = 2$، $\text{vol}\, S = 2k$ $\Longrightarrow$ النسبة $\frac{2}{\min(2k,\ 12-2k)}$ $\Longrightarrow$ الأدنى عند $k = 3$: $\frac{2}{6} = \frac{1}{3}$ $\Longrightarrow$ $h = \frac{1}{3}$، و $1 - \cos\frac{\pi}{3} = 0.5 \leq \frac{2}{3}$ $\Longrightarrow$ $\frac{1/9}{2} = 0.056 \leq 0.5 \leq \frac{2}{3}$. ✓ (23) $\lambda(L) = (0, 4, 4, 4)$؛ $\lambda(L_{\text{sym}}) = (0,\ \frac{4}{3},\ \frac{4}{3},\ \frac{4}{3})$. (24) $g(\lambda) = \lambda(\lambda_{\max} - \lambda)$ مضروباً بثابت، أي $g(L) = L(\lambda_{\max} I - L)$.

المجموعة هـ — بيرون–فروبينيوس و PageRank (25–30)

تمرين 25. احسب $\rho(A)$ ومتجه بيرون لـ $A = \begin{bmatrix} 1 & 2 \\ 3 & 1 \end{bmatrix}$.

تمرين 26. استخدم كولاتس–فيلانت بـ $x = (1,\ 1)^{\top}$ ثم $x = (1,\ 1.5)^{\top}$ لتضييق الحدود على $\rho(A)$ في التمرين السابق.

تمرين 27. ابنِ مصفوفة جوجل لرسم من 3 صفحات: $1 \to 2$، $1 \to 3$، $2 \to 1$، $3 \to 1$ بـ $\alpha = 0.15$ واحسب تكرارين.

تمرين 28. كم تكراراً يلزم لتقارب PageRank بدقة 10^{-4} إذا كان $\alpha = 0.2$؟

تمرين 29. بيّن أن $|\lambda_2(G)| \leq 1 - \alpha$ باستخدام حقيقة أن كل صفوف G موجبة بالقدر α/n.

تمرين 30. احسب درجات HITS (hubs و authorities) للرسم الموجّه $A = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$.

إجابات مختصرة (هـ): (25) $\lambda^2 - 2\lambda - 5 = 0$ $\Longrightarrow$ $\rho = 1 + \sqrt{6} = 3.449$؛ $v \propto (\sqrt{2},\ \sqrt{3})^{\top}$ $\Longrightarrow$ $v = (0.449,\ 0.551)^{\top}$ بـ $\|\cdot\|_1$. (26) $x = (1,1)$: $Ax = (3,4)$؛ $\rho \in [3,\ 4]$ $\Longrightarrow$ نسب $4,\ 3$ $\Longrightarrow$ $x = (1, 1.5)$: $Ax = (4,\ 4.5)$؛ $\rho \in [3, 4]$ $\Longrightarrow$ (لا تحسّن $\Longrightarrow$ اختر x أقرب لبيرون). بـ $x = (0.45,\ 0.55)$: $Ax = (1.55,\ 1.90)$، نسب 3.444 و 3.455 $\Longrightarrow$ $\rho \in [3.444,\ 3.455]$ ✓ (الحقيقي 3.449). (27) $G = 0.05J + 0.85P$؛ $(\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ بالتناظر. (28) $k \geq \frac{\ln(5\times10^{-5})}{\ln 0.8} = \frac{-9.903}{-0.2231} = 44.4$ $\Longrightarrow$ 45 تكراراً. (29) كما في برهان (42.4): لأي $x \perp \mathbf{1}$ فإن $Gx = (1-\alpha)Px$. (30) $AA^{\top} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}$، $h = (0,\ 0.526,\ 0.851)^{\top}$ $\Longrightarrow$ $A^{\top}A = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix}$؛ و $\lambda_1 \approx 2.857$ $\Longrightarrow$ $a \approx (0.404,\ 0.660,\ 0.635)^{\top}$ تقريباً.

جدول النظريات الخمس

#	النظرية / القانون	الصيغة الجوهرية	التطبيق الرئيسي في الذكاء الاصطناعي
1	**التحليل الطيفي**	$A = Q\Lambda Q^\top = \sum_i \lambda_i q_i q_i^\top$، وكايلي–هاملتون، ودوال المصفوفات	PCA، التبييض، Neural ODE، استقرار التدريب
2	**SVD** + إيكارت–يونغ	$A = U\Sigma V^\top$؛ أفضل تقريب رتبة k بخطأ σ_{k+1} (طيفي) و $\sqrt{\sum_{i>k}\sigma_i^2}$ (فروبينيوس)	الضغط، LoRA، LSA، إكمال المصفوفات، التطبيع الطيفي
3	رايلي–ريتز وفايل	$\lambda_k = \min\max R_A(x)$؛ $\lvert\lambda_i(A+E)-\lambda_i(A)\rvert \le \lVert E\rVert_2$؛ $\sin\theta \le \lVert E\rVert_2/\delta$	ضبط معدّل التعلّم، تحليل التكميم، استقرار PCA
4	طيف اللابلاس وفيدلر	$L = D - W$؛ $x^\top Lx = \sum w_{ij}(x_i - x_j)^2$؛ λ_2 يحكم القطع وشيغير	التجميع الطيفي، GNN، تقسيم الصور، كشف المجتمعات
5	بيرون–فروبينيوس	$\rho(A)$ بسيطة بمتجه موجب؛ $\pi = \pi G$؛ $\lVert\lambda_2\rVert \le 1-\alpha$	PageRank، مركزية العُقد، أنظمة التوصية، كشف الاحتيال

المبادئ الخمسة الحاكمة

١. **الاتجاهات التي لا تُدار:** القيم الذاتية تخبرنا أين «يتمدّد» التحويل وأين «ينضغط»؛ هذه هي محاور البيانات.

٢. **الرتبة الفعّالة $\ll$ البعد الظاهري:** منحنى القيم المفردة هو أهم أداة تشخيص في تعلم الآلة؛ «الكوع» يحدّد البعد الحقيقي.

٣. **الفجوة الطيفية هي عملة الاستقرار:** فجوة كبيرة $\Longrightarrow$ متجهات مستقرّة وتقارب سريع؛ فجوة صغيرة $\Longrightarrow$ انهيار.

٤. **الاضطرابات محدودة بمتراجحات:** فايل للقيم، هوفمان–فيلانت للمجموع، ديفيس–كاهان للمتجهات، كوشي للتداخل.

٥. **الإيجابية تمنح الوحودية:** المصفوفات غير السالبة تعطي متجهاً ذاتياً موجباً وحيداً $\Longrightarrow$ ترتيبٌ «عادل» وحيد.

مسار القراءة للأجزاء القادمة

طيف المصفوفات هو الأداة التي سنحتاجها في:

- **الجزء الثاني (التفاضل والتكامل):** الهسيان (مصفوفة متماثلة) $\Longrightarrow$ القيم الذاتية تحدّد نوع النقطة الحرجة وسرعة التقارب.
- **الجزء الثالث (الاحتمالات):** مصفوفات التغاير $\Longrightarrow$ PCA الاحتمالي والعوامل الكامنة.
- **الجزء الرابع (التحسين):** رقم الحالة $\kappa = \sigma_1/\sigma_n$ $\Longrightarrow$ سرعة التدرّج وطرق نيوتن.
- **الجزء السابع (رياضيات التعلم العميق):** Kernel Tangent Neural $\Longrightarrow$ طيف NTK يحكم التعميم؛ ومصفوفات الانتباه $\Longrightarrow$ طيفها يحكم الاستقرار.
- **الجزء الثامن (البنى المتقدمة):** الهندسة المعلوماتية $\Longrightarrow$ مترية فيشر، والنقل الأمثل $\Longrightarrow$ طيف نواة النقل.

القيم الذاتية والتحليل الطيفي

الرمز	المعنى
λ	القيمة الذاتية (eigenvalue)
λ_i	القيمة الذاتية رقم i (تنازلياً في §٤.٤–٢.٤، تصاعدياً في §٥.٤)
$v,\ q,\ u_i$	المتجه الذاتي (eigenvector)
Λ	مصفوفة قطرية للقيم الذاتية

مصفوفة متعامدة للمتجهات الذاتية	Q
كثيرة الحدود المميِّزة	$p_A(\lambda)$
طيف A (مجموعة قيمها الذاتية)	$\mathrm{spec}(A)$
التكرار الجبري	$\mathrm{alg}(\lambda)$
التكرار الهندسي	$\mathrm{geo}(\lambda)$
الأثر (trace)	$\mathrm{tr}(A)$
المحدِّد	$\det(A)$
موجب التحديد / نصف موجب التحديد	$\succ,\ \succeq$
نصف القطر الطيفي	$\rho(A)$
الأُسّ الماتريسي	e^{At}
دالة المصفوفة	$f(A)$
خارج قسمة رايلي	$R_A(x)$
الفجوة الطيفية	δ
رقم الحالة	$\kappa(A)$

القيم المفردة والرتبة

المعنى	الرمز
القيمة المفردة رقم i	σ_i
مصفوفة القيم المفردة	Σ
المتجهات المفردة اليسرى واليمنى	$U,\ V$
المتجه المفرد الأيسر/الأيمن	$u_i,\ v_i$
رتبة المصفوفة	r
الرتبة المستهدفة في التقريب	k
النورم الطيفي	$\|\cdot\|_2$
نورم فروبينيوس	$\|\cdot\|_F$
النورم النووي	$\|\cdot\|_*$
المعكوس الشمولي	$A^\dagger$
الأشكال المقتطعة (thin)	$U_k,\ \Sigma_k,\ V_k$

الرسوم والاضطراب

المعنى	الرمز
الرسم البياني	$G = (V, E)$
مصفوفة المجاورة	W
مصفوفة الدرجات	D
لابلاس الرسم	L
اللابلاس المطبَّع تماثلياً	L_{sym}
لابلاس السير العشوائي	L_{rw}
متجه فيدلر	f
ثابت شيغير	$h(G)$
حجم مجموعة العُقَد	$\mathrm{vol}(S)$
حدود المجموعة (الروابط المقطوعة)	∂S
مصفوفة الاضطراب	E
المصفوفة المضطربة	$\hat{A}$
مصفوفة الزوايا الرئيسية	$\Theta(U, \hat{U})$
مرشِّح طيفي على الرسم	$g(L)$

بيرون–فروبينيوس و PageRank

الرمز	المعنى
$A \geq 0$	مصفوفة غير سالبة
α	معامل التخفيف (teleport)
P	مصفوفة الانتقال
G	مصفوفة جوجل
π	توزيع PageRank
c	مركزية المتجه الذاتي
$h,\ a$	درجات المراكز والسلطات (HITS)
$\mathbf{1}$	متجه الواحدات
$J = \mathbf{1}\mathbf{1}^\top$	مصفوفة الواحدات

١. **G. Strang,** (2016). *Introduction to Linear Algebra*, 5th ed. Wellesley-Cambridge Press. — الفصول 6 و 7: القيم الذاتية و SVD.

٢. **D. Bau, & N., L. Trefethen,** (1997). *Numerical Linear Algebra*. SIAM. — المحاضرات 4–5 و 24–31: SVD والخوارزميات الطيفية.

٣. **F. C. Loan, Van & H., G. Golub,** (2013). *Matrix Computations*, 4th ed. Johns Hopkins. — المرجع الحسابي الشامل.

٤. **R. C. Johnson, & A., R. Horn,** (2012). *Matrix Analysis*, 2nd ed. Cambridge University Press. — متراجحات فايل وهوفمان–فيلانت وكوران–فيشر.

٥. **R. C. Johnson, & A., R. Horn,** (1991). *Topics in Matrix Analysis*. Cambridge. — بيرون–فروبينيوس بتفصيل وافٍ.

٦. **D. C. Meyer,** (2000). *Matrix Analysis and Applied Linear Algebra*. SIAM. — الفصل 7: القيم الذاتية، والفصل 8: بيرون–فروبينيوس و PageRank.

٧. **G. Young, & C., Eckart,** (1936). «The approximation of one matrix by another of lower rank». *Psychometrika* 1 (3), 211–218. — الأصل التاريخي لنظرية التقريب الأمثل.

٨. **L. Mirsky,** (1960). «Symmetric gauge functions and unitarily invariant norms». *Q. J. Math.* 11, 50–59. — التعميم لأي نورم ثابت وحدوياً.

٩. **M. W. Kahan, & C., Davis,** (1970). «The rotation of eigenvectors by a perturbation. III». *SIAM J. Numer. Anal.* 7 (1), 1–46. — متراجحة ديفيس–كاهان.

١٠. **J. Sun, & W., G. Stewart,** (1990). *Matrix Perturbation Theory*. Academic Press. — المرجع الكامل لنظرية الاضطراب.

١١. **K. R. F. Chung,** (1997). *Spectral Graph Theory*. AMS/CBMS. — المرجع الكلاسيكي لطيف الرسوم ومتراجحة شيغير.

١٢. **U. Luxburg, Von** (2007). «A tutorial on spectral clustering». *Statistics and Computing*, 17 (4), 395–416. — العرض المرجعي للتجميع الطيفي والفجوة الطيفية.

١٣. **M. Fiedler,** (1973). «Algebraic connectivity of graphs». *Czechoslovak J. Math.* 23, 298–305. — الأصل التاريخي لمتجه فيدلر.

١٤. **V. Milman, & N., Alon,** (1985). «λ_1, isoperimetric and graphs, for inequalities superconcentrators». *J. Combin. Theory B*, 38, 73–88. — العلاقة بين λ_2 وثابت شيغير.

١٥. **M. Welling, & N., T. Kipf,** (2017). «Semi-supervised classfiication with graph convolutional networks». *ICLR*. — صيغة GCN الطيفية.

١٦. **P. Vandergheynst, & X., Bresson, M., Defferrard,** (2016). «Convolutional neural networks on graphs with fast localized spectral filtering». *NeurIPS*. — مرشّح تشيبيشيف (ChebNet).

١٧. **T. Winograd, & R., Motwani, S., Brin, L., Page,** (1999). «The citation PageRank ranking». *Report Tech Stanford*. — الأصل التاريخي.

١٨. **D. C. Meyer, & N., A. Langville,** (2006). *Google's PageRank and Beyond*. Princeton University Press. — التحليل الشامل لـ PageRank و HITS.

١٩. **M. J. Kleinberg,** (1999). «Authoritative sources in a hyperlinked environment». *J. ACM*, 46(5), 604–632. — خوارزمية HITS.

٢٠. **T., Miyato, et al.** (2018). «Spectral normalization for generative adversarial networks». *ICLR*. — التطبيع الطيفي في GAN.

٢١. **E. Hu, J., et al.** (2022). «LoRA: Low-rank adaptation of large language models». *ICLR*. — التقريب من رتبة منخفضة في الضبط الدقيق.

٢٢. **S., Kornblith, et al.** (2019). «Similarity of neural network representations revisited». *ICML*. — CKA والزوايا الرئيسية لمقارنة التمثيلات.

٢٣. **M. Wofl, & O., Ledoit,** (2004). «A well-conditioned estimator for large-dimensional covariance matrices». *J. Multivariate Anal.*, 88, 365–411. — تقدير التغاير بالانكماش (shrinkage).

الفصل القادم: النواظم (Norms)، المسافات، ومتراجحات المصفوفات — حيث نعمّم مفهوم «الطول» و«المسافة» على فضاءات المصفوفات والدوال، ونبني المتراجحات التي يقوم عليها الاستقرار العددي والتعميم في تعلم الآلة.

الفصل ٥

النواظم، (Norms) المسافات، ومتراجحات المصفوفات

الهدف من الفصل

أن تعطي معنى دقيقاً لكلمة «طول» و«مسافة» و«قرب» في فضاءات المتجهات والمصفوفات والدوال، ثم أن تمتلك **المتراجحات** — وهي الأداة التي تحوّل «الطول» إلى **ضمان**: ضمان تقارب، ضمان استقرار، ضمان تعميم، ضمان متانة أمام الاضطراب. كل حدّ تعميم (generalization bound) وكل تحليل استقرار وكل إثبات تقارب في تعلم الآلة هو في جوهره متراجحة على ناظم.

لماذا هذا الفصل هو «لُغة الحدود» في الكتاب؟

في الفصول السابقة تعلّمنا **بنية** الفضاء (المجموعات، الفضاءات المتجهة، المصفوفات، القيم الذاتية). في هذا الفصل نتعلّم **القياس**: كم يبعد شيء عن شيء؟ وكم يمكن أن يكبر خطأ؟ وكم يلزم من البيانات؟

السؤال في الذكاء الاصطناعي	الناظم/المتراجحة التي تجيب عنه
هل سيتقارب التدرّج العشوائي (SGD)؟	الناظم الإقليدي + متراجحة المثلث + التضاعف التحتي
هل النموذج متين أمام اضطراب في المدخلات (adversarial)؟	ℓ_2 و ℓ_∞ وناظم المشغّل $\|W\|_2$ (ثابت ليبشيتز)
كيف نحصل على نموذج متناثر (sparse)؟	كرة ℓ_1 لها زوايا $\Rightarrow$ تدفع الحل إلى الصفر (Lasso)
كيف نكمل مصفوفة ناقصة (توصية)؟	الناظم النووي $\|A\|_*$ بديل مقعّب للرتبة
كيف نضغط الأوزان أو نقيس «حجم» التحديث؟	نواظم شاتن: $\|A\|_2$، $\|A\|_F$، $\|A\|_*$
هل توزيعان قريبان؟	مسافات على التوزيعات: KL، TV، Wasserstein
كم بُعداً نحتاج لنحفظ المسافات؟	لمّا جونسون–ليندنشتراوس (JL)
هل سينفجر التدرّج أم يتلاشى؟	حاصل ناظم المشغّل: $\prod_k \|W_k\|_2$ وتركيز ناظم المصفوفة العشوائية
هل التضمينات (embeddings) تحفظ المعنى؟	تركيز النواظم + متراجحة المثلث على المسافات

خريطة الفصل

القسم	الموضوع	القوانين/النظريات	عدد الأمثلة المحلولة
1.5	المفردات: مسلّمات الناظم، المترية، نواظم ℓ_p	(1.5)–(7.5)	—
2.5	متراجحات كوشي–شفارتس وهولدر ومينكوفسكي + الناظم الثنوي	(8.5)–(12.5)	15
3.5	تكافؤ النواظم في الأبعاد المنتهية وحدود التحويل	(13.5)–(18.5)	15
4.5	النواظم المصفوفية المستحثة والتضاعف التحتي ونصف القطر الطيفي	(19.5)–(25.5)	15
5.5	نواظم شاتن ومتراجحة فون نيومان للأثر وازدواج النواظم المصفوفية	(26.5)–(32.5)	15
6.5	تركّز النواظم ولمّا جونسون–ليندنشتراوس وناظم المصفوفة العشوائية	(33.5)–(39.5)	15
7.5	تمارين محلولة ومفتوحة (30 تمريناً)	—	—
8.5	خلاصة الفصل	—	—
9.5	فهرس الرموز	—	—
10.5	المراجع	—	—

كيف تقرأ هذا الفصل

كل نظرية تأتي في **أربع طبقات** إلزامية:

١. **صياغة رسمية** في كتلة معادلة مستقلة مرقّمة بـ \tag{}.

٢. **جدول رموز** يشرح كل رمز ومعامل في المعادلة.

٣. **رسم هندسي** (SVG) يترجم المعادلة إلى صورة.

٤. **برهان** كامل أو مرجعي.

ثم خمس طبقات تطبيقية: 15 مثالاً واقعياً محلولاً بخطوات مرقّمة ⟵ جدول أخطاء شائعة ⟵ تمارين ⟵ فهرس رموز ⟵ مراجع.

> **قاعدة ذهبية تسبق كل شيء:** في تعلم الآلة لا تختار الناظم لأنه «أدقّ»، بل لأن **كرة الوحدة** الخاصة به لها الشكل الذي يخدم هدفك: كرة ℓ_1 مُعيَّنة الزوايا ⟹ تناثر؛ كرة ℓ_2 ملساء ⟹ استقرار عددي وتماسك؛ كرة ℓ_∞ مُربَّعة ⟹ أسوأ حالة على بُعد واحد؛ كرة الناظم النووي ⟹ رتبة منخفضة.

1.1.5 تعريف الناظم (Norm)

ليكن V فضاءً متجهاً على $\mathbb{R}$ (أو $\mathbb{C}$). **الناظم** (norm) على V هو دالة $\|\cdot\| : V \to \mathbb{R}$ تحقّق المسلّمات الأربع التالية لكل $x, y \in V$ وكل ثابت قياسي α:

(1.5)

$$x = 0 \iff \|x\| = 0, \quad \|x\| \geq 0$$ (N1) غير سالب ومحدِّد:

$$\|\alpha x\| = |\alpha|\,\|x\|$$ (N2) متجانس إطلاقاً:

$$\|x + y\| \leq \|x\| + \|y\|$$ (N3) متراجحة المثلث:

$$\|x\| = \sqrt{\langle x,\, x\rangle}$$ (N4) (لازم للدوال على الفضاءات الداخلية) الارتباط بالضرب الداخلي:

جدول رموز (1.5):

الرمز	المعنى	ملاحظات
V	فضاء متجهي (vector space) على $\mathbb{R}$ أو $\mathbb{C}$	قد يكون $\mathbb{R}^n$، أو فضاء مصفوفات، أو فضاء دوال
$\|\cdot\|$	الناظم: دالة من V إلى $\mathbb{R}_{\geq 0}$	تُقرأ «ناظم x» = «norm of x»
x, y	متجهات (أو مصفوفات، أو دوال) عناصرُ الفضاء V	—
α	ثابت قياسي (scalar) من حقل الفضاء $\mathbb{R}$ أو $\mathbb{C}$	—
$\|\alpha\|$ في (N2)	القيمة المطلقة لـ α (أو معيارها المركّب)	تكتب $\|\alpha\|$ — بخطّين عموديين صغيرين
0	متجه الصفر في V	(N1) تقول: الصفر وحده ناظمه صفر
$\langle x, y\rangle$	الضرب الداخلي (inner product)	يُولّد ناظماً عبر $\|x\| = \sqrt{\langle x, x\rangle}$
(N1)	«positive definiteness» — اللاسلبية والتحديد	بدونه نحصل على «شبه ناظم» (seminorm)
(N2)	«absolute homogeneity» — التجانس المطلق	يمنع تضخم الناظم بالسالب
(N3)	«triangle inequality» — متراجحة المثلث	هي التي تجعل الناظم «مسافة»
(N4)	الشرط الإقليدي: الناظم آتٍ من ضرب داخلي	ليس كل ناظم يحقّقه: ℓ_1 وℓ_∞ لا يحقّقانه
$\iff$	«إذا وفقط إذا»	في (N1) تقرأ: «ناظم x يساوي صفراً **إذا وفقط إذا** كان x نفسه صفراً»

ملاحظة: إذا سقط شرط $\|x\| = 0 \Rightarrow x = 0$ فقط، صارت الدالة **شبه ناظم** (seminorm). مثال مهم في تعلم الآلة: $\|f\| = \|Wf\|_2$ حيث W غير قابلة للعكس — فهي تلغي اتجاهات كاملة.

2.1.5 الناظم يُولّد مترية (مسافة)

كل ناظم يُولّد **مسافة** (metric) / (distance بالعلاقة:

$$d(x,\,y) \;=\; \|\,x - y\,\| \tag{2.5}$$

وهذه المسافة تحقّق مسلّمات المترية الأربع:

$$\begin{aligned}
&\text{(M1)} \quad d(x,y) \geq 0, \quad d(x,y) = 0 \iff x = y \\
&\text{(M2)} \quad d(x,y) = d(y,x) \quad \text{(تناظر)} \\
&\text{(M3)} \quad d(x,z) \leq d(x,y) + d(y,z) \quad \text{(متراجحة المثلث)} \\
&\text{(M4)} \quad d(x+a,\;y+a) = d(x,y) \quad \text{(ثبات بالانتقال — يتبع من التجانس المطلق)}
\end{aligned} \tag{3.5}$$

جدول رموز (2.5)–(3.5):

الرمز	المعنى	ملاحظات
$d(x,y)$	المسافة بين x و y	القيمةُ عددٌ حقيقي غير سالب
$x-y$	فرق المتجهين	في فضاء المتجهات يُعرَّف بالطرح المعتاد
(M1)	المسافة لاسالبة وتصفّر **فقط** عند التطابق	يتبع من (N1)
(M2)	التناظر	يتبع من (N2) مع $\alpha=-1$: $\|x-y\| = \|-(y-x)\| = \|y-x\|$
(M3)	متراجحة المثلث للمسافة	يتبع من (N3): $x-z = (x-y)+(y-z)$
(M4)	الثبات بالانتقال (translation invariance)	خاصية تميّز المسافات الآتية من ناظم
a	متجه انتقال (offset) اختياري	—

تنبيه: ليست كل مسافة آتية من ناظم. أمثلة مهمة في تعلم الآلة: مسافة كولباك–ليبلر (ليست مترية: غير متناظرة، ولا تحقّق المثلث)، ومسافة جنسن–شانون (مترية بعد أخذ الجذر)، ومسافة واسرشتاين (مترية حقيقية وآتية من ناظم على فضاء دوال مزدوج). سنفصّلها في الجزء الخامس (نظرية المعلومات) والجزء الثامن.

3.1.5 عائلة نواظم ℓ_p

أهم عائلة نواظم على $\mathbb{R}^n$ هي عائلة ℓ_p المعرّفة لكل $p \in [1,\infty]$ بـ:

$$\|x\|_p \;=\; \begin{cases} \Big(\displaystyle\sum_{i=1}^{n} |x_i|^p\Big)^{1/p}, & 1 \leq p < \infty \\[2mm] \displaystyle\max_{1\leq i\leq n} |x_i|, & p = \infty \end{cases} \tag{4.5}$$

الحالات الثلاث الأكثر استخداماً:

$$\|x\|_1 = \sum_{i=1}^{n} |x_i|, \qquad \|x\|_2 = \sqrt{\sum_{i=1}^{n} x_i^2}, \qquad \|x\|_\infty = \max_i |x_i| \tag{5.5}$$

جدول رموز (4.5)–(5.5):

الرمز	المعنى	ملاحظات
p	أُسّ الناظم، (order) عدد حقيقي في $[1, \infty]$	ليس عدداً طبيعياً بالضرورة
x_i	الإحداثي (المكوّن) رقم i للمتجه x	$x = (x_1, \dots, x_n)^\top$
$\|x_i\|$ في الصيغة	القيمة المطلقة للإحداثي	مكتوبة $\|x_i\|$
$\sum_{i=1}^{n}$	مجموع على كل الإحداثيات من 1 إلى n	—
$(\cdot)^{1/p}$	الجذر الـ p	يضمن التجانس (N2)
n	بُعد الفضاء	يظهر صراحةً في حدود التحويل بين النواظم
$\max_i$	أكبر إحداثي بالمقياس المطلق	حالة $p = \infty$
$\|x\|_1$	«ناظم مانhattan» أو ناظم مجموع القيم المطلقة	يولّد التناثر
$\|x\|_2$	الناظم الإقليدي	الناظم الوحيد الآتي من الضرب الداخلي القياسي
$\|x\|_\infty$	ناظم «أقصى قيمة مطلقة» = ناظم تشيبيشيف	يضبط أسوأ حالة
$0 < p < 1$	**ليس** ناظماً: ينكسر (N3)	يولّد «شبه ناظم» مقعّب محلياً فقط

تحذير شائع: الصيغة $\|x\|_p = (\sum |x_i|^p)^{1/p}$ عند $0 < p < 1$ **لا تُعطي ناظماً** لأن متراجحة المثلث **تفشل. مثال:** $x = (1,0),\ y = (0,1)$ على $\mathbb{R}^2$ مع $p = \frac{1}{2}$: $\|x + y\|_{1/2} = 4 > 2 = \|x\|_{1/2} + \|y\|_{1/2}$. لهذا تُستخدم ℓ_p بـ $p < 1$ فقط كـ «بديل مقعّب للتناثر» مع خوارزميات خاصّة.

4.1.5 الناظم الآتي من ضرب داخلي عام (ومصفوفة القياس)

كل مصفوفة G متماثلة موجبة التحديد (SPD) تُعرّف ناظماً عبر:

$$\|x\|_G = \sqrt{x^\top G\, x}, \qquad G = G^\top \succ 0 \tag{6.5}$$

وهذا يعمّم الناظم الإقليدي (الذي يقابل $G = I$). في تعلم الآلة يظهر هذا بصيغتين:

$$d_M(x,y) = \sqrt{(x-y)^\top M (x-y)} \quad ; \quad \text{(Metric learning)} \qquad d_G(x,y) = \sqrt{(x-y)^\top \Sigma^{-1} (x-y)} \quad \text{(Mahalanobis)} \tag{7.5}$$

جدول رموز (6.5)–(7.5):

الرمز	المعنى	ملاحظات
G	مصفوفة القياس (metric matrix)	$n \times n$
$G = G^\top$	G متماثلة	شرط لازم ليكون الضرب الداخلي متناظراً
$G \succ 0$	G موجبة التحديد: $x^\top G x > 0$ لكل $x \neq 0$	شرط لازم لـ (N1)
$x^\top G x$	الشكل التربيعي (quadratic form)	عدد حقيقي ≥ 0
$\sqrt{\cdot}$	الجذر التربيعي	يحقّق التجانس (N2)
Σ	مصفوفة التغاير (covariance) للبيانات	
Σ^{-1}	معكوس التغاير = مصفوفة الدقّة (precision matrix)	«يُبيّض» البيانات
d_G, d_M	مسافة مالانوبيس ومسافة متعلَّمة	يعاقب الاتجاهات عالية التباين
M	مصفوفة متعلَّمة (مثلاً $M = L^\top L$)	أساس تعلّم المسافة (metric learning) و kNN الموزون
I	مصفوفة الوحدة	غالباً تُقنَّن بـ $M \succeq 0$ وبأثر ثابت
		$G = I \Rightarrow \|x\|_G = \|x\|_2$

ملاحظة هندسية: كرة الوحدة $\{x : \|x\|_G \leq 1\}$ هي **قطع ناقص** محاورُه متجهاتُ G الذاتية، وأطوالُ أنصاف محاوره $1/\sqrt{\lambda_i(G)}$. هذا هو «الشكل» الذي تتخذه البيانات بعد التبييض (whitening): $x \mapsto \Sigma^{-1/2} x$.

الفكرة في سطر: الضرب الداخلي لمدخلين لا يمكن أن يتجاوز **حاصل ضرب طوليهما**، والفرق بينهما هو بالضبط جيبُ تمامِ الزاوية بينهما. هذه الحقيقة الواحدة — بعد تعميمها من ℓ_2 إلى أي زوج (p, q) مترافق — تُنتج كلَّ متراجحة أخرى في هذا الفصل.

1.2.5 الصياغة الرسمية

نظرية (كوشي–شفارتس — Cauchy–Schwarz).

ليكن V فضاءً بضرب داخلي، وليكن $x, y \in V$. عندئذٍ:

$$\begin{aligned} \big|\langle x,\, y\rangle\big| \;&\le\; \|x\|_2\,\|y\|_2 \\ \big|\langle x,\, y\rangle\big| = \|x\|_2\|y\|_2 \;&\iff\; \exists\,\alpha\in\mathbb{R}:\; y=\alpha x \;\text{ أو }\; x=\alpha y \end{aligned} \tag{8.5}$$

وإذا كان $x \neq 0$ و $y \neq 0$ فإن الزاوية θ بينهما تُعرَّف بالصيغة المكافئة:

$$\cos\theta \;=\; \frac{\langle x,\, y\rangle}{\|x\|_2\,\|y\|_2} \;\in\; [-1,\,1], \qquad \theta = \arccos\!\left(\frac{\langle x,\, y\rangle}{\|x\|_2\|y\|_2}\right)$$

جدول رموز (8.5):

الرمز	المعنى	ملاحظات
$\langle x, y\rangle$	الضرب الداخلي (inner product) بين x و y	على $\mathbb{R}^n$: $\langle x,y\rangle = \sum_i x_i y_i = x^\top y$
$\|\langle x, y\rangle\|$	القيمة المطلقة للضرب الداخلي	بدونها تفشل المتراجحة عند $\langle x,y\rangle$ سالب كبير
$\|x\|_2,\ \|y\|_2$	الناظمان الإقليديان: $\|x\|_2 = \sqrt{\langle x,x\rangle}$	حاصل ضربهما هو «السقف»
$\le$	المتراجحة: الطرف الأيسر $\le$ الطرف الأيمن دائماً	تساوي فقط عند التوازي
$\iff$	«إذا وفقط إذا» — شرط التساوي	يفيد في كشف التبعية الخطية
α	ثابت التناسب (أي عدد حقيقي)	قد يكون صفراً أو سالباً
$\cos\theta$	جيب تمام الزاوية بين المتجهين	قيمته في $[-1,1]$ بفضل كوشي–شفارتس
θ	الزاوية بالراديان (أو بالدرجات)	$\theta=0$: نفس الاتجاه؛ $\theta=\pi$: اتجاهان متعاكسان؛ $\theta=\pi/2$: تعامد
arccos	الدالة العكسية لجيب التمام	مداها $[0,\pi]$ راديان
$x \neq 0$	شرط لتجنّب القسمة على صفر	إذا كان أحدهما صفراً فالزاوية غير معرّفة

نظرية (هولدر — Hölder).

ليكن $p, q \in [1,\infty]$ **أُسّين مترافقين** (conjugate exponents)، أي $\frac{1}{p}+\frac{1}{q}=1$. عندئذٍ لكل $x, y \in \mathbb{R}^n$:

$$\sum_{i=1}^{n}\big|x_i\,y_i\big| \;=\; \big\|\,x\odot y\,\big\|_1 \;\le\; \|x\|_p\,\|y\|_q \tag{9.5}$$

بصيغة الضرب الداخلي: $|\langle x,y\rangle| \le \sum_i |x_i y_i| \le \|x\|_p\|y\|_q$. **والحالات الحدّية:** $(p,q) = (1,\infty)$ و $(p,q)=(2,2)$ — والأخيرة هي بالضبط كوشي–شفارتس.

جدول رموز (9.5):

الرمز	المعنى	ملاحظات
p	أُسّ الناظم الأول	$1 \le p \le \infty$
q	أُسّ الناظم الثاني = الأُسّ المترافق	$1 < p < \infty$ عندما $q = \frac{p}{p-1}$
$\frac{1}{p} + \frac{1}{q} = 1$	**شرط الترافق** (conjugacy)	جوهري: بدونه تفشل المتراجحة
x_i, y_i	الإحداثيّان رقم i في المتجهين	—
$\lvert x_i y_i \rvert$	القيمة المطلقة لجداء الإحداثيين	—
$\sum_{i=1}^{n}$	المجموع على كل الإحداثيات	—
$x \odot y$	جداء هادامارد (إحداثياً بإحداثي)	$(x \odot y)_i = x_i y_i$
$\lVert x \odot y \rVert_1$	مجموع قيم جداء هادامارد المطلقة	مساوٍ للطرف الأيسر
$\lVert x \rVert_p$	ناظم ℓ_p للمتجه x	$(\sum \lvert x_i \rvert^p)^{1/p}$
$\lVert y \rVert_q$	ناظم ℓ_q للمتجه y	—
$p = 1, q = \infty$	الحالة الحدية الأولى: $\sum \lvert x_i y_i \rvert \le \lVert x \rVert_1 \lVert y \rVert_\infty$	أساس تحليل المتانة بـ ℓ_∞
$p = q = 2$	الحالة الحدية الثانية = كوشي–شفارتس	الحالة «الذاتية الترافق»
$q = p/(p-1)$	صيغة حساب الأُسّ المترافق	$p = 4 \Rightarrow q = 4/3$ ،$p = 1.5 \Rightarrow q = 3$

نظرية (مينكوفسكي — Minkowski = متراجحة المثلث لـ ℓ_p).

لكل $1 \le p \le \infty$ وكل $x, y \in \mathbb{R}^n$:

$$\lVert x + y \rVert_p \;\le\; \lVert x \rVert_p + \lVert y \rVert_p \tag{10.5}$$

وبالتعميم على أي عدد من الحدود وبالصيغة الفرقية:

$$\Big\lVert \sum_{k=1}^{K} x^{(k)} \Big\rVert_p \;\le\; \sum_{k=1}^{K} \lVert x^{(k)} \rVert_p, \qquad \big|\, \lVert x \rVert_p - \lVert y \rVert_p \,\big| \;\le\; \lVert x - y \rVert_p \tag{10b.5}$$

جدول رموز (10.5):

الرمز	المعنى	ملاحظات
$x + y$	مجموع المتجهين إحداثياً بإحداثي	$(x+y)_i = x_i + y_i$
$\lVert x + y \rVert_p$	ناظم ℓ_p للمجموع	الطرف الأيسر: «طول الضلع الثالث»
$\lVert x \rVert_p + \lVert y \rVert_p$	مجموع ناظمي الضلعين	الطرف الأيمن: «طول الطريق عبر y»
$1 \le p \le \infty$	مجال الأُسّ الذي تصحّ فيه المتراجحة	عند $p < 1$ **تفشل** المتراجحة
$x^{(k)}$	المتجه رقم k في مجموعة من K متجهات	العلوي بين قوسين: رقم المتجه لا أُسّ
K	عدد المتجهات المجموعة	مثلاً عدد خطوات التراكم في التدرّج
$\lVert x \rVert_p - \lVert y \rVert_p$	فرق الناظمين	القيمة المطلقة تمحي من الإشارة
يمين (10b.5)	**المتراجحة الفرقية** (reverse triangle)	تضبط «كم يمكن أن يختلف الناظمان»
$\le$	اتجاه المتراجحة: «المباشر أقصر من الملتوي»	—

تعريف (الناظم الثنوي — Dual norm).

لكل ناظم $\lVert \cdot \rVert$ على $\mathbb{R}^n$ نعرّف ناظمه الثنوي:

$$\lVert z \rVert_* \;=\; \sup\big\{\, \langle z,\, x \rangle \;:\; \lVert x \rVert \le 1 \,\big\} \;=\; \max_{\lVert x \rVert = 1} \langle z,\, x \rangle \tag{11.5}$$

ويتحقّق: **(أ)** المتراجحة المعمّمة $\lvert \langle z, x \rangle \rvert \le \lVert z \rVert_* \, \lVert x \rVert$؛ **(ب)** $(\ell_p)^* = \ell_q$ بالترافق $\frac{1}{p} + \frac{1}{q} = 1$؛ **(ج)** $(\lVert \cdot \rVert_*)^* = \lVert \cdot \rVert$ (ثنوية الثنوي يعيد الأصل)؛ **(د)** $\lVert z \rVert = \max_{\lVert w \rVert_* \le 1} \langle z, w \rangle$.

جدول رموز (11.5):

الرمز	المعنى	ملاحظات
z	المتجه المراد قياس ناظمه الثنوي	يلعب دور «الوحشة» أو «الشكل الخطي»
$\|\cdot\|_*$	الناظم الثنوي (dual norm)	النجمة علامة الاصطلاح
sup	الحدّ الأعلى (supremum) للمجموعة	هنا يتحقّق كـ max لأن كرة الوحدة متراصّة
$\{\,\|x\| \le 1\,\}$	كرة الوحدة المغلقة للناظم الأصلي	مجموعة الاختبار
$\langle z, x\rangle$	الشكل الخطي الذي نُعظّمه	إسقاط x على z
$\max_{\|x\|=1}$	التعظيم على سطح الكرة	يكافئ التعظيم على الكرة لأن الشكل خطي
$(\ell_p)^* = \ell_q$	ثنوي ℓ_p هو ℓ_q	$p=2 \Rightarrow q=2$، $p=1 \Rightarrow q=\infty$
$(\|\cdot\|_*)_* = \|\cdot\|$	الازدواج انعكاسي (reflexive)	صحيح في الأبعاد المنتهية دائماً
$\|z\| = \max_{\|w\|_*\le 1}\langle z, w\rangle$	إعادة بناء الناظم من ثنويه	كل ناظم = دالة دعم لكرته الثنوية
w	متجه الاختبار في صيغة إعادة البناء	يتراوح على الكرة الثنوية

لمّة (يونغ — Young) — أداة البرهان:

$$a\,b \;\le\; \frac{a^p}{p} + \frac{b^q}{q}, \qquad a,b \ge 0, \quad \tfrac{1}{p}+\tfrac{1}{q}=1 \tag{12.5}$$

الرمز	المعنى	ملاحظات
a, b	عددان حقيقيان غير سالبين	يمثّلان $\|x_i\|$ و $\|y_i\|$ بعد التطبيع
a^p/p	الجزء الأول من حدّ يونغ	الأُسّ p يقابل الناظم الأول
b^q/q	الجزء الثاني من حدّ يونغ	الأُسّ q المترافق
p, q	الأُسّان المترافقان	$1/p + 1/q = 1$
التساوي	يتحقّق عند $a^p = b^q$	وهو ما يعطي شرط التساوي في هولدر

الشكل الهندسي للمتراجحة (8.5): الإسقاطُ أقصرُ من المتجه، والمسافةُ بينهما هي «الجزء المتعامد» من y على x:

$$\big\| y - \operatorname{proj}_x y \big\|_2^2 \;=\; \|y\|_2^2 - \frac{\langle x,y\rangle^2}{\|x\|_2^2} \;=\; \|y\|_2^2\big(1-\cos^2\theta\big)$$

شكل الناظم الثنوي: المستوى الداعم للكرة في النقطة المُعظِّمة:

2.2.5 البرهان

برهان كوشي-شفارتس (8.5).

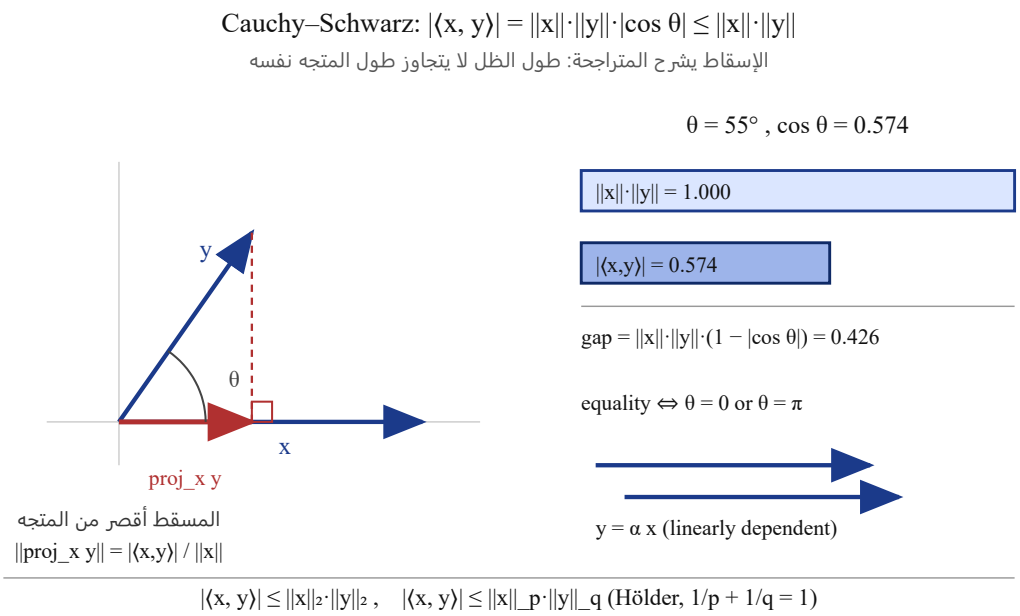
إذا كان $y = 0$ فالمتراجحة بديهية $(0 \le 0)$. وإلا، فليكن $\alpha \in \mathbb{R}$ حرّاً، ومن (N1) مع المتجه $x - \alpha y$:

$$0 \;\le\; \|x - \alpha y\|_2^2 \;=\; \|x\|_2^2 - 2\alpha\langle x,y\rangle + \alpha^2\|y\|_2^2$$

الطرف الأيمن كثيرُ حدودٍ تربيعي في α لا سالب أبداً، فمميّزه غير موجب:

$$\Delta \;=\; 4\langle x,y\rangle^2 - 4\|x\|_2^2\|y\|_2^2 \;\le\; 0 \quad\Longrightarrow\quad \langle x,y\rangle^2 \le \|x\|_2^2\|y\|_2^2$$

وبأخذ الجذر: $|\langle x,y\rangle| \le \|x\|_2\|y\|_2$. والتساوي يعني $\Delta = 0$، أي وجود جذر حقيقي مكرّر $\alpha^\star$ مع $\|x - \alpha^\star y\|_2 = 0$، أي $x = \alpha^\star y$. ■



شكل ١٠٥: *
متراجحة كوشي–شفارتس هندسياً: الإسقاط والزاوية

برهان هولدر (9.5).

بلا فقدان العمومية نفترض $\|x\|_p > 0$ و $\|y\|_q > 0$ (وإلا فأحدهما صفر والمتراجحة بديهية). نُطبّع:

$$\tilde{x}_i = \frac{|x_i|}{\|x\|_p}, \qquad \tilde{y}_i = \frac{|y_i|}{\|y\|_q} \quad \Longrightarrow \quad \|\tilde{x}\|_p = \|\tilde{y}\|_q = 1$$

نُطبق لمّة يونغ (12.5) على $a = \tilde{x}_i$ و $b = \tilde{y}_i$:

$$\tilde{x}_i\,\tilde{y}_i \;\le\; \frac{\tilde{x}_i^{\,p}}{p} + \frac{\tilde{y}_i^{\,q}}{q}$$

ونجمع على $i = 1, \dots, n$:

$$\frac{\sum_i |x_i y_i|}{\|x\|_p \|y\|_q} \;=\; \sum_i \tilde{x}_i \tilde{y}_i \;\le\; \frac{1}{p}\underbrace{\sum_i \tilde{x}_i^{\,p}}_{=\,\|\tilde{x}\|_p^p = 1} + \frac{1}{q}\underbrace{\sum_i \tilde{y}_i^{\,q}}_{=\,\|\tilde{y}\|_q^q = 1} \;=\; \frac{1}{p} + \frac{1}{q} \;=\; 1$$

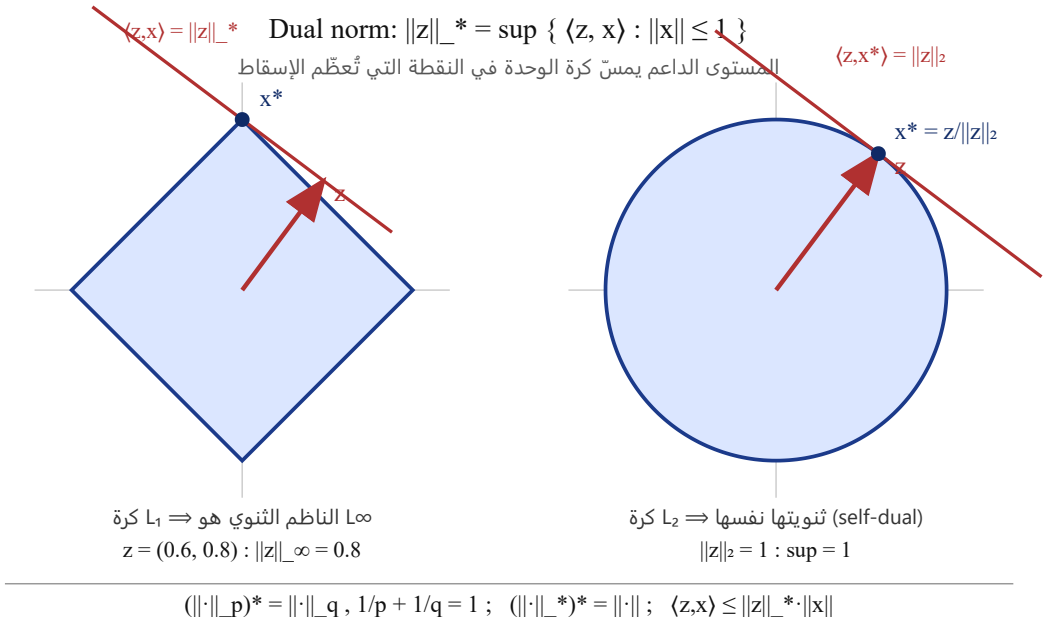
فنحصل على $\sum_i |x_i y_i| \le \|x\|_p \|y\|_q$. والتساوي يتطلّب $\tilde{x}_i^{\,p} = \tilde{y}_i^{\,q}$ لكل i — أي أن الشعاعين $|x|^p$ و $|y|^q$ متناسبان. ■

برهان مينكوفسكي (10.5).

نفصل الحالتين:

الحالة $p = 1$: $|x_i + y_i| \le |x_i| + |y_i|$ (متراجحة المثلث للأعداد الحقيقية)، وبالجمع: $\|x+y\|_1 \le \|x\|_1 + \|y\|_1$.

الحالة $1 < p < \infty$: ليكن q مترافقاً مع p. من متراجحة المثلث العددية ثم هولدر:



شكل ٢.٥: *
الناظم الثنوي: مستوى داعم يمسّ كرة الوحدة

$$\begin{aligned}\|x+y\|_p^p &= \sum_i |x_i+y_i|^p = \sum_i |x_i+y_i|^{p-1}\,|x_i+y_i| \\ &\le \sum_i |x_i+y_i|^{p-1}\big(|x_i|+|y_i|\big) \\ &= \sum_i |x_i+y_i|^{p-1}|x_i| \;+\; \sum_i |x_i+y_i|^{p-1}|y_i| \\ &\le \big\||x+y|^{p-1}\big\|_q\big(\|x\|_p+\|y\|_p\big)\end{aligned}$$

ولأن $(p-1)q = p$ نجد $\big\||x+y|^{p-1}\big\|_q = \big(\sum_i |x_i+y_i|^{(p-1)q}\big)^{1/q} = \|x+y\|_p^{p/q}$. إذن:

$$\|x+y\|_p^p \;\le\; \|x+y\|_p^{p/q}\big(\|x\|_p+\|y\|_p\big)$$

وبالقسمة على $\|x+y\|_p^{p/q}$ (إن كان غيرَ صفر، وإلا فالمتراجحة بديهية) وبملاحظة $p-\frac{p}{q} = p(1-\frac{1}{q}) = p\cdot\frac{1}{p} = 1$:

$$\|x+y\|_p \;\le\; \|x\|_p + \|y\|_p \qquad \blacksquare$$

برهان صيغة الناظم الثنوي (11.5).

من هولدر: $\langle z,x\rangle \le \sum_i |z_i x_i| \le \|z\|_q\|x\|_p$، فـ $\|z\|_* \le \|z\|_q$. ولإثبات العكس نبني متجه الاختبار الذي يحقّق التساوي. ليكن ($1 < p < \infty$ لـ):

$$x_i^\star \;=\; \frac{\operatorname{sgn}(z_i)\,|z_i|^{q-1}}{\|z\|_q^{q-1}}$$

فإن $\|x^\star\|_p = 1$ (تحقّق مباشر: $\sum_i |z_i|^{(q-1)p} = \sum_i |z_i|^q$ لأن $(q-1)p = q$)، و:

$$\langle z,\, x^\star \rangle \;=\; \frac{\sum_i |z_i|^q}{\|z\|_q^{q-1}} \;=\; \|z\|_q$$

إذن $\|z\|_* = \|z\|_q$. وحالة $p=1$: نختار $x^\star = \operatorname{sgn}(z_{i_0})\, e_{i_0}$ عند الإحداثي الأكبر، فنحصل $\|z\|_* = \|z\|_\infty$. وحالة $p=2$: $x^\star = z/\|z\|_2$ فنحصل $\|z\|_* = \|z\|_2$ — أي أن ℓ_2 **ثنوي نفسه** (sefl-dual). ■

3.2.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (5.2-1): تشابه جيب التمام بين تضمينين نصيّين — التحقّق من متراجحة كوشي-شفارتس

المعطيات: تضمينان لجملتين من نموذج لغوي، بُعد التضمين $n = 4$:

$$x = (2,\, -1,\, 3,\, 0)^\top, \qquad y = (1,\, 4,\, -2,\, 1)^\top$$

المطلوب: احسب $\cos\theta$ وتحقّق صراحةً من $|\langle x, y\rangle| \le \|x\|_2 \|y\|_2$، ثم قدر «الفسحة» (slack).

الحل:

١. الضرب الداخلي: $\langle x, y\rangle = 2\cdot 1 + (-1)\cdot 4 + 3\cdot(-2) + 0\cdot 1 = 2 - 4 - 6 + 0 = -8$.

٢. الناظمان: $\|x\|_2 = \sqrt{4+1+9+0} = \sqrt{14} = 3.7417$، و $\|y\|_2 = \sqrt{1+16+4+1} = \sqrt{22} = 4.6904$.

٣. حاصل الضرب (السقف): $\|x\|_2\|y\|_2 = 3.7417 \times 4.6904 = 17.549$.

٤. المتراجحة: $|\langle x, y\rangle| = 8 \le 17.549$ ✓ — والتحقّق ناجح.

٥. جيب التمام: $\cos\theta = -8/17.549 = -0.4559$، والزاوية $\theta = \arccos(-0.4559) \approx 117.1^\circ$.

٦. الفسحة: $\|x\|_2\|y\|_2 - |\langle x, y\rangle| = 17.549 - 8 = 9.549$.

النتيجة: $\cos\theta = -0.4559$ — الجملتان «متباعدتان دلالياً» (زاوية منفرجة)، والفسحة 9.549 تؤكّد أنهما غير متوازيتين.

الربط بالذكاء الاصطناعي: تشابه جيب التمام هو مقياس الاسترجاع الافتراضي في أنظمة RAG والبحث الدلالي. كوشي-شفارتس هي الضمانة الرياضية بأن النتيجة دائماً في $[-1, 1]$، فلا حاجة إلى «قصّ» اصطناعي. كما أن الفسحة تفسّر لماذا يُفضّل تطبيع التضمينات: عندها $\cos\theta = \langle \hat{x}, \hat{y}\rangle$ والترتيب لا يتأثر بأطوال المتجهات.

مثال (5.2-2): تقييد قرابة الانتباه (attention score) والتحجيم بـ $1/\sqrt{d_k}$

المعطيات: في طبقة انتباه، $d_k = 8$، والمتجهان:

$$q = (1.2,\, -0.5,\, 0.8,\, 1.0,\, -0.3,\, 0.6,\, 0.9,\, -1.1)^\top$$
$$k = (0.7,\, 1.1,\, -0.9,\, 0.4,\, 1.3,\, -0.2,\, 0.5,\, 0.8)^\top$$

المطلوب: احسب القرابة الخام $s = q^\top k$ والقرابة المُحَجَّمة $s/\sqrt{d_k}$، وقارن كلتيهما بسقف كوشي–شفارتس.
الحل:

١. القرابة الخام: $s = 0.84 - 0.55 - 0.72 + 0.40 - 0.39 - 0.12 + 0.45 - 0.88 = -0.97$.

٢. الناظمان: $\|q\|_2 = \sqrt{1.44 + 0.25 + 0.64 + 1.00 + 0.09 + 0.36 + 0.81 + 1.21} = \sqrt{5.80} = 2.4083$، و $\|k\|_2 = \sqrt{5.29} = 2.3000$.

٣. السقف قبل التحجيم: $|s| \le 2.4083 \times 2.3000 = 5.539$. والتحقّق: $0.97 \le 5.539$ ✓.

٤. بعد التحجيم: $s/\sqrt{8} = -0.97/2.8284 = -0.3430$، والسقف الجديد $5.539/2.8284 = 1.958$.

٥. لماذا التحجيم؟ إذا كانت مكوّنات q, k مستقلة بتباين 1، فإن $\mathrm{Var}(q^\top k) = d_k = 8$، أي انحراف معياري $\sqrt{8} = 2.83$. القسمة على $\sqrt{d_k}$ تُعيد الانحراف المعياري إلى ≈ 1.

النتيجة: السقف انخفض من 5.539 إلى 1.958، والقرابة نفسها من -0.97 إلى -0.343.
الربط بالذكاء الاصطناعي: هذا بالضبط سبب وجود $\frac{1}{\sqrt{d_k}}$ في صيغة الانتباه المُقنّع (scaled dot-product attention) في «Transformer» بدونه تكبر القرابات مع d_k فتدفع softmax إلى منطقة التشبّع حيث التدرجات شبه صفرية — أي تجمّد التعلّم. كوشي–شفارتس تعطي السقف الأقصى، والتحجيم يضبط **التباين النموذجي** لا السقف.

مثال (2.5-3): متانة نموذج خطي أمام اضطراب ℓ_∞ — هولدر بـ $(p, q) = (1, \infty)$

المعطيات: نموذج خطي $f(x) = w^\top x$ بأوزان $w = (0.4, -1.2, 0.9, -0.3, 0.7)^\top$ ومدخل يتعرّض لاضطراب δ بشرط $\|\delta\|_\infty \le \varepsilon = 0.05$.
المطلوب: أقصى تغيّر ممكن في خرج النموذج، والاضطراب الذي يحقّقه.
الحل:

١. التغيّر في الخرج: $\Delta f = w^\top \delta$ (النموذج خطي).

٢. بهولدر مع $(p, q) = (1, \infty)$: $|\Delta f| \le \|w\|_1 \, \|\delta\|_\infty$.

٣. $\|w\|_1 = 0.4 + 1.2 + 0.9 + 0.3 + 0.7 = 3.5$، فالسقف $= 3.5 \times 0.05 = 0.175$.

٤. الاضطراب الأمثل يحقّق التساوي: $\delta_i^\star = \varepsilon \, \mathrm{sgn}(w_i) = 0.05\,(1, -1, 1, -1, 1)^\top$.

٥. التحقّق: $w^\top \delta^\star = 0.05\,(0.4 + 1.2 + 0.9 + 0.3 + 0.7) = 0.05 \times 3.5 = 0.175$ — **يبلغ السقف تماماً.**

٦. مقارنة بميزانية ℓ_2: لو كان $\|\delta\|_2 \le 0.05$ بدلاً من ذلك، فالسقف $= \|w\|_2 \|\delta\|_2 = \sqrt{2.99} \times 0.05 = 1.7292 \times 0.05 = 0.0865$ — أصغر، لأن كرة ℓ_2 نصف قطرها 0.05 محتواة في كرة ℓ_∞ بالمواصفات نفسها.

النتيجة: تحت $\|\delta\|_\infty \le 0.05$، أقصى تغيّر هو 0.175؛ وتحت $\|\delta\|_2 \le 0.05$ هو 0.0865.
الربط بالذكاء الاصطناعي: هذه هي الحسابات التي تقف خلف هجمات FGSM/PGD وخلف «التدريب الخصمي» (adversarial training). المبدأ العام: **ميزانية الاضطراب تُعيّن الناظم، والناظم الثنوي يُعيّن ما يجب تقليله في الأوزان.** لميزانية ℓ_∞: قلّل $\|w\|_1$ (تناثر). ولميزانية ℓ_2: قلّل $\|w\|_2$ (تنعيم). لهذا يختلف نوع التنظيم باختلاف نموذج التهديد.

مثال (5.2.4): حساب الناظم الثنوي لثلاثة نواظم مختلفة والتحقّق من $(\ell_p)^* = \ell_q$

المعطيات: $z = (3,\, -1,\, 4,\, 0,\, 2)^\top$.

المطلوب: احسب $\|z\|_*$ بالنسبة إلى الناظم الأصلي في الحالات الثلاث ℓ_1، ℓ_2، ℓ_∞، وابحث متجه الاختبار $x^\star$ الذي يحقّق التساوي في كل حالة.

الحل:

١. **الأصل ℓ_∞ ⟸ الثنوي ℓ_1:** $\|z\|_* = \|z\|_1 = 3+1+4+0+2 = 10$. متجه الاختبار: $x^\star = \operatorname{sgn}(z) = (1,\, -1,\, 1,\, 0,\, 1)^\top$. التحقّق: $\|x^\star\|_\infty = 1$ و $\langle z, x^\star\rangle = 3+1+4+0+2 = 10$ ✓.

٢. **الأصل ℓ_1 ⟸ الثنوي ℓ_∞:** $\|z\|_* = \max_i |z_i| = 4$. متجه الاختبار: $x^\star = e_3 = (0,0,1,0,0)^\top$ (وحدة عند الإحداثي الأكبر، بإشارة $+4$ موجبة). التحقّق: $\|x^\star\|_1 = 1$ و $\langle z, x^\star\rangle = 4$ ✓.

٣. **الأصل ℓ_2 ⟸ الثنوي ℓ_2:** $\|z\|_* = \|z\|_2 = \sqrt{9+1+16+0+4} = \sqrt{30} = 5.4772$. متجه الاختبار: $x^\star = z/\|z\|_2 = (0.5477,\, -0.1826,\, 0.7303,\, 0,\, 0.3651)^\top$. التحقّق: $\langle z, x^\star\rangle = \|z\|_2^2/\|z\|_2 = \|z\|_2 = 5.4772$ ✓.

٤. التحقّق من الانعكاسية: $(\|\cdot\|_*)^* = \|\cdot\|$ — فثنوي ℓ_∞ هو ℓ_1، وثنوي ℓ_1 هو ℓ_∞ ✓.

النتيجة: $\|z\|_* = 4$ (أصل ℓ_1)، 5.4772 (أصل ℓ_2)، 10 (أصل ℓ_∞).

الربط بالذكاء الاصطناعي: صيغة الناظم الثنوي هي التي تُنتج **كل** حدود التعميم الشائعة. حدّ «margin» لنموذج خطي تحت اضطراب ℓ_∞ هو $\propto \|w\|_1$؛ وتحت ℓ_2 هو $\propto \|w\|_2$. وصيغة $\|z\| = \max_{\|w\|_*\le 1}\langle z, w\rangle$ هي التي تُستخدم في تحليل Rademacher «complexity» في الجزء السادس (نظرية التعلّم الإحصائي).

مثال (5.2.5): تراكم التدرّجات وقصّها — مينكوفسكي والمتراجحة الفرقية

المعطيات: تدرّجان من دفعتين فرعيّتين (micro-batches): $g_1 = (0.8,\, -1.4,\, 0.3)^\top$ و $g_2 = (-0.5,\, 0.9,\, 1.1)^\top$. ميزانية القصّ $c = 1.0$.

المطلوب: تحقّق من متراجحة المثلث والمتراجحة الفرقية، وقارن «القصّ المشترك» بـ «القصّ لكل دفعة على حدة».

الحل:

١. $\|g_1\|_2 = \sqrt{0.64 + 1.96 + 0.09} = \sqrt{2.69} = 1.6401$؛ و $\|g_2\|_2 = \sqrt{0.25 + 0.81 + 1.21} = \sqrt{2.27} = 1.5067$.

٢. المجموع: $g = g_1 + g_2 = (0.3,\, -0.5,\, 1.4)^\top$؛ $\|g\|_2 = \sqrt{0.09 + 0.25 + 1.96} = \sqrt{2.30} = 1.5166$.

٣. مينكوفسكي: $\|g\|_2 \le \|g_1\|_2 + \|g_2\|_2$، أي $1.5166 \le 1.6401 + 1.5067 = 3.1468$ ✓ — والفسحة كبيرة لأن المتجهين **غير متوازيين**.

٤. المتراجحة الفرقية: $\big|\|g_1\|_2 - \|g_2\|_2\big| = 0.1334 \le \|g_1 - g_2\|_2 = \|(1.3,\, -2.3,\, -0.8)\|_2 = \sqrt{7.62} = 2.7604$ ✓.

٥. القصّ المشترك: معامل القصّ $c/\|g\|_2 = 1.0/1.5166 = 0.6594$، والتحديث المقصوص $0.6594\, g$ = ناظمه 1.0 بالضبط.

٦. القصّ المنفصل: معاملا القصّ $0.6097 = 1.0/1.6401$ و $0.6637 = 1.0/1.5067$. المجموع $g_1 + 0.6637 g_2 = (0.1559,\ -0.2563,\ 0.9130)^\top$، وناظمه $\sqrt{0.9236} = 0.9611$.

النتيجة: القصّ المشترك يعطي تحديثاً ناظمه 1.0 (يستنفد الميزانية ويحفظ الاتجاه)؛ والقصّ المنفصل يعطي 0.9611 (أصغر من اللازم — يفقد معلومة) ويُغيّر الاتجاه.

الربط بالذكاء الاصطناعي: مينكوفسكي تخبرنا أن $\|\sum_k g_k\| \le \sum_k \|g_k\|$ — والحدّ الأيمن **فضفاض جداً** حين تكون التدرّجات متعامدة أو متعاكسة. لهذا تُطبّق مكتبات التدريب الموزّع القصّ على **المجموع العالمي** بعد التجميع (all-reduce)، لا على كل نسخة على حدة: الناظم الحقيقي للمجموع قد يكون أصغر بكثير من مجموع النواظم، وتقديره بالمجموع يبالغ في القصّ.

مثال (5.2-6): الارتباط بين ميزتين مركزيّتين — كوشي–شفارتس في فضاء L^2

المعطيات: ميزتان مقيسَتان على $n = 5$ عيّنات، ومُمركَزتان (متوسط كل منهما صفر):

$$x_1 = (1.2,\ -0.8,\ 0.3,\ -1.5,\ 0.8)^\top, \qquad x_2 = (0.9,\ -1.1,\ 0.5,\ -0.7,\ 0.4)^\top$$

المطلوب: احسب معامل الارتباط (correlation) وتحقّق أنه في $[-1, 1]$ بفعل كوشي–شفارتس.

الحل:

١. التحقّق من التمركز: $\bar{x}_1 = (1.2 - 0.8 + 0.3 - 1.5 + 0.8)/5 = 0$ ✓، $\bar{x}_2 = (0.9 - 1.1 + 0.5 - 0.7 + 0.4)/5 = 0$ ✓.

٢. الضرب الداخلي: $\langle x_1, x_2 \rangle = 1.08 + 0.88 + 0.15 + 1.05 + 0.32 = 3.48$.

٣. الناظمان: $\|x_1\|_2 = \sqrt{1.44 + 0.64 + 0.09 + 2.25 + 0.64} = \sqrt{5.06} = 2.2494$؛ $\|x_2\|_2 = \sqrt{0.81 + 1.21 + 0.25 + 0.49 + 0.16} = \sqrt{2.92} = 1.7088$.

٤. الارتباط: $\rho = \dfrac{\langle x_1, x_2 \rangle}{\|x_1\|_2 \|x_2\|_2} = \dfrac{3.48}{2.2494 \times 1.7088} = \dfrac{3.48}{3.8436} = 0.9054$.

٥. كوشي–شفارتس: $|3.48| \le 3.8436$ ✓، و $|\rho| = 0.9054 \le 1$ ✓.

النتيجة: $\rho = 0.9054$ — الميزتان مرتبطتان ارتباطاً إيجابياً قوياً، ولولا كوشي–شفارتس لما كان مضموناً أن يقع الارتباط في $[-1, 1]$.

الربط بالذكاء الاصطناعي: الارتباط هو كوشي–شفارتس **مطبّقاً على فضاء المتغيّرات العشوائية** L^2 مع الضرب الداخلي $\langle X, Y \rangle = \mathbb{E}[XY]$. هذه القراءة نفسها تعطي: $|\mathrm{Cov}(X, Y)| \le \sigma_X \sigma_Y$، وكل حدود التباين في تعلّم التعزيز (مثل تحليل تباين مقدّر السياسة) هي كوشي–شفارتس متخفّية.

مثال (5.2-7): العلاقة الدقيقة بين مسافة ℓ_2 وتشابه جيب التمام على تضمينات مُطبَّعة

المعطيات: تضمينان مُطبَّعان $\|\hat{x}\|_2 = \|\hat{y}\|_2 = 1$، وتشابههما $\cos\theta = 0.85$.
المطلوب: احسب $\|\hat{x} - \hat{y}\|_2$ من التشابه مباشرةً، وتحقّق بالمثال الصريح.
الحل:

١. بتوسيع المربع: $\|\hat{x} - \hat{y}\|_2^2 = \|\hat{x}\|_2^2 + \|\hat{y}\|_2^2 - 2\langle \hat{x}, \hat{y} \rangle$.

٢. بما أن الطولين $= 1$ و $\langle \hat{x}, \hat{y} \rangle = \cos\theta$:

$$\|\hat{x} - \hat{y}\|_2^2 \;=\; 1 + 1 - 2\cos\theta \;=\; 2(1 - \cos\theta)$$

٣. بالتعويض: $\|\hat{x} - \hat{y}\|_2 = \sqrt{2(1 - 0.85)} = \sqrt{0.30} = 0.5477$.

٤. تحقّق صريح: ليكن $\hat{x} = (1, 0)^\top$ و $\hat{y} = (0.85,\, 0.5268)^\top$ (حيث $0.5268 = \sqrt{1 - 0.85^2}$ $= \sqrt{0.2775}$). إذن $\|\hat{x} - \hat{y}\|_2^2 = (1 - 0.85)^2 + (0 - 0.5268)^2 = 0.0225 + 0.2775 = 0.3000$ ✓، فالمسافة $= 0.5477$ ✓.

النتيجة: على المتجهات المُطبَّعة: $\|\hat{x} - \hat{y}\|_2 = \sqrt{2(1 - \cos\theta)}$ — ترتيب المسافة الإقليدية **مطابق تماماً** لترتيب التشابه (لأن الجذر تابع monotonically increasing).

الربط بالذكاء الاصطناعي: هذه المتطابقة تفسّر لماذا لا فرق عملياً بين «أقرب الجيران بالمسافة الإقليدية» و«الأعلى تشابهاً» على تضمينات مُطبَّعة — وهو ما تفعله قواعد بيانات المتجهات (FAISS، Annoy) وتفسّر أيضاً لماذا تُطبَّع التضمينات قبل الفهرسة: التطبيع يُلغي أثر أطوال المتجهات ويجعل الناظمَين متكافئين ترتيبياً.

مثال (8-2.5): فحص صلاحية مصفوفة نواة (Gram) بمتراجحة كوشي–شفارتس

المعطيات: مصفوفة نواة مقترحة على ثلاث عيّنات:

$$K = \begin{pmatrix} 4 & 2.9 & 1.1 \\ 2.9 & 2.25 & 0.8 \\ 1.1 & 0.8 & 0.36 \end{pmatrix}$$

المطلوب: تحقّق من شرط كوشي–شفارتس $|K_{ij}| \;\le\; \sqrt{K_{ii}K_{jj}}$ لكل زوج، ثم من كون K موجبة التحديد، وقدّر حالة التكييف (conditioning).
الحل:

١. الزوج $(1,2)$: $|2.9| \le \sqrt{4 \times 2.25} = \sqrt{9} = 3$ ✓ — شبه مُحكم.

٢. الزوج $(1,3)$: $|1.1| \le \sqrt{4 \times 0.36} = \sqrt{1.44} = 1.2$ ✓.

٣. الزوج $(2,3)$: $|0.8| \le \sqrt{2.25 \times 0.36} = \sqrt{0.81} = 0.9$ ✓.

٤. شرط كوشي–شفارتس **ضروري ولا يكفي**؛ نتحقّق من المُنَّات الرائدة لـ Sylvester: $4 > 0$، و $4 \times 2.25 - 2.9^2 = 9 - 8.41 = 0.59 > 0$، و $\det K = 4(0.81 - 0.64) - 2.9(1.044 - 0.88) + 1.1(2.32 - 2.475) = 0.68 - 0.4756 - 0.1705 = 0.0339 > 0$. إذن $K \succ 0$ ✓.

٥. كثير الحدود المميِّز: $\operatorname{tr} K = 6.61$، ومجموع المُنَّات الرائدة $2 \times 2 \; 0.99 = 0.59 + 0.23 + 0.17 =$، فـ $\lambda^3 - 6.61\lambda^2 + 0.99\lambda - 0.0339 = 0$، وجذوره $\lambda \approx (6.456,\ 0.103,\ 0.051)$.

٦. حالة التكييف: $\kappa = \lambda_{\max}/\lambda_{\min} \approx 6.456/0.051 \approx 127$.

النتيجة: المصفوفة نواة صالحة، لكنها **سيّئة التكييف** ($\kappa \approx 127$) لأن الزوج $(1, 2)$ شبه متوازٍ.

الربط بالذكاء الاصطناعي: في ridge SVM/kernel regression، مخالفة $|K_{ij}| \le \sqrt{K_{ii}K_{jj}}$ تكشف فوراً نواة غير صالحة (خطأ في التنفيذ أو في المقياس). والتقارب الشديد من حدّ كوشي–شفارتس **إنذار مبكر بسوء التكييف** قبل حساب أي قيمة ذاتية: سينهار حلّ الانحدار أو سيتطلّب تنظيماً كبيراً. القاعدة العملية: راقب $\max_{i \neq j} |K_{ij}| / \sqrt{K_{ii}K_{jj}}$؛ كلما اقترب من 1 اقتربت المصفوفة من الانفراد.

مثال (٥.٢-9): ثلاث ميزانيات اضطراب وثلاثة نواظم ثنوية — جدول المتانة الكامل

المعطيات: نموذج خطي بأوزان $w = (6,\ -8,\ 3,\ 9)^{\top}$، وميزانية اضطراب $\varepsilon = 0.1$ تُقاس بثالثة نواظم مختلفة.

المطلوب: أقصى تغيّر في الخرج $|\Delta f| \le \varepsilon \|w\|_*$ لكل ميزانية، والاضطراب الأمثل في كل حالة.

الحل:

١. النواظم الأساسية: $\|w\|_1 = 6 + 8 + 3 + 9 = 26$؛ $\|w\|_2 = \sqrt{36 + 64 + 9 + 81} = \sqrt{190} = 13.784$؛ $\|w\|_\infty = 9$.

٢. **ميزانية ℓ_2** $\Longrightarrow$ الثنوي ℓ_2: $|\Delta f| \le 0.1 \times 13.784 = 1.378$، ويحقَّق بـ $\delta^\star = 0.1\, w/\|w\|_2$.

٣. **ميزانية ℓ_1** $\Longrightarrow$ الثنوي ℓ_∞: $|\Delta f| \le 0.1 \times 26 = 2.60$، ويحقَّق بـ $\delta^\star = 0.1 \operatorname{sgn}(w) = (0.1,\ -0.1,\ 0.1,\ 0.1)^{\top}$.

٤. **ميزانية ℓ_∞** $\Longrightarrow$ الثنوي ℓ_1: $|\Delta f| \le 0.1 \times 9 = 0.90$، ويحقَّق بـ $\delta^\star = 0.1\, e_4$ (الإحداثي ذو أكبر $|w_i|$).

٥. الترتيب: $0.90 < 1.378 < 2.60$ — وهو ترتيب **احتواء الكرات**: $B_1(0.1) \subset B_2(0.1) \subset B_\infty(0.1)$ على $\mathbb{R}^4$.

النتيجة: أخطر ميزانية هي ℓ_∞ (تغيّر 2.60) وأضعفها ℓ_1 (تغيّر 0.90).

الربط بالذكاء الاصطناعي: هذا الجدول هو «خريطة التهديد» الكاملة لتقييم المتانة. الميزانية ℓ_∞ هي المعيار في رؤية الحاسوب (تغيّر كل بكسل قليلاً لا يُرى بالعين لكنه يقلب القرار). والميزانية ℓ_1 تناسب «تعديل عدد محدود من الكلمات». اختيار الميزانية ليس تفصيلاً تقنياً: **الميزانيةُ تحدّد الناظم الثنوي، والثنوي يحدّد التنظيم الذي يقي فعلاً.**

مثال (٥.٢-10): هولدر بأُسّين غير مألوفين $(p, q) = (4, \frac{4}{3})$ على التدرّج وزخمه

المعطيات: تدرّج $g = (0.5,\ -2.0,\ 1.5,\ -0.25,\ 3.0)^{\top}$ ومتجه زخم ثانٍ غير سالب $v = (0.1,\ 0.4,\ 0.25,\ 0.05,\ 0.6)^{\top}$.

المطلوب: تحقّق من هولدر $\sum_i |g_i v_i| \le \|g\|_4 \, \|v\|_{4/3}$ رقمياً، وقارن بكوشي–شفارتس $(p, q) = (2, 2)$.

الحل:

١. $\frac{1}{4}+\frac{1}{q}=1\Rightarrow q=\frac{4}{3}$ ✓ (ترافق).

٢. $\|g\|_4=\left(0.5^4+2^4+1.5^4+0.25^4+3^4\right)^{1/4}=\left(0.0625+16+5.0625+0.0039+81\right)^{1/4}=(102.129)^{1/4}=3.179$.

٣. $v_i^{4/3}=(0.0464,\ 0.2947,\ 0.1575,\ 0.0184,\ 0.5060)$، حيث $\|v\|_{4/3}=\left(\sum_i v_i^{4/3}\right)^{3/4}$، مجموعها 1.0231؛ إذن $\|v\|_{4/3}=(1.0231)^{0.75}=1.0173$.

٤. سقف هولدر: $3.179\times 1.0173=3.234$.

٥. القيمة الفعلية: $\sum_i|g_iv_i|=0.05+0.80+0.375+0.0125+1.80=3.0375\le 3.234$ ✓.

٦. مقارنة بـ $(2,2)$: $\|g\|_2=\sqrt{0.25+4+2.25+0.0625+9}=\sqrt{15.5625}=3.9449$؛ $\|v\|_2=\sqrt{0.01+0.16+0.0625+0.0025+0.36}=\sqrt{0.595}=0.7714$، السقف $=3.0433$ — وهو **أحكم** قليلاً من 3.234 هنا.

النتيجة: كلا السقفين صحيح: $3.0375\le 3.0433$ (كوشي-شفارتس) و $3.0375\le 3.234$ (هولدر بـ $(4,\frac{4}{3})$). أيهما أحكم يعتمد على شكل المتجهين.

الربط بالذكاء الاصطناعي: لا يوجد زوج «أفضل دائماً»؛ **تختار الأُسّين بحسب ما تعرفه عن المتجهين.** إذا كان لأحدهما ذيل ثقيل (قيم قليلة كبيرة جداً — كما في تدرّجات الطبقات العميقة أو نسب الأهمية في تعلّم السياسات خارج السياسة)، فالأُسّ الأكبر p يلتقط الذيل؛ وإذا كان الآخر مسطحاً فالأُسّ الأصغر يكفي. مرونة هولدر هي بالضبط ما يجعل حدود التعميم قابلة للتكييف مع توزيع الأخطاء.

مثال (2.5-11): دمج نماذج مضبوطة دقيقاً (task vectors) — متى تكون مينكوفسكي فضفاضة؟

المعطيات: متجهان للمهام (فروق أوزان بعد الضبط الدقيق): $\tau_1=(0.30,\ -0.12,\ 0.45,\ 0.08)^\top$ و $\tau_2=(-0.18,\ 0.33,\ 0.10,\ -0.25)^\top$.

المطلوب: احسب ناظم المجموع المدمج، وتحقّق من مينكوفسكي، وفسّر الفسحة بالتشابه بين المتجهين.

الحل:

١. $\|\tau_1\|_2=\sqrt{0.09+0.0144+0.2025+0.0064}=\sqrt{0.3133}=0.5597$؛ $\|\tau_2\|_2=\sqrt{0.0324+0.1089+0.01+0.0625}=\sqrt{0.2138}=0.4624$.

٢. المجموع: $\tau=(0.12,\ 0.21,\ 0.55,\ -0.17)^\top$؛ $\|\tau\|_2=\sqrt{0.0144+0.0441+0.3025+0.0289}=\sqrt{0.3899}=0.6244$.

٣. مينكوفسكي: $0.6244\le 0.5597+0.4624=1.0221$ ✓؛ الفسحة $=0.3977$ — كبيرة جداً.

٤. التفسير: $\langle\tau_1,\tau_2\rangle=-0.054-0.0396+0.045-0.02=-0.0686$؛ $\cos\theta=-0.0686/(0.5597\times 0.4624)=-0.0686/0.2588=-0.2651$.

٥. تحقّق بالمتطابقة: $\|\tau_1+\tau_2\|_2^2=0.3133+0.2138+2(-0.0686)=0.3899$ ✓ — التداخل **سالب**، فالمجموع أقصر مما تتوقّع مينكوفسكي.

٦. الدمج المُقاس: $\|\frac{1}{2}\tau\|_2 = 0.3122$.

النتيجة: الدمج يعطي ناظماً 0.6244 بدلاً من السقف 1.0221، لأن المهام متعارضة جزئياً ($\cos\theta = -0.265$).
الربط بالذكاء الاصطناعي: دمج النماذج (model arithmetic) task / merging يعتمد على هذه الحساب بالضبط. إذا كان $\cos(\tau_1, \tau_2) < 0$ فالدمج **يُضعف** كلا المتجهين (تداخل هدّام)؛ وإذا كان $1 \approx$ فينكوفسكي شبه مُحكمة والدمج يجمع الطولين. لذلك تُقاس «زاوية المهمة» قبل الدمج، وتُستخدم خوارزميات مثل TIES/DARE لإزالة المكوّنات المتعارضة إحداثياً قبل الجمع.

مثال (5.2-12): الفحص الآمن (safe screening) في Lasso — الناظم الثنوي يُلغي الحل كله

المعطيات: مصفوفة تصميم X بأعمدة $x_1 = (1.2, -0.6, 0.3)^\top$، $x_2 = (1.6, 1.2, 0.8)^\top$، $x_3 = (0.5, -0.4, 0.6)^\top$؛ ومتبقٍّ $r = (0.5, -0.3, 0.2)^\top$؛ ومعامل تنظيم $\lambda = 1.5$.
المطلوب: قرّر — بدون تشغيل محلّل Lasso — هل الحل متجه الأصفار.
الحل:

١. شرط KKT ليكون $w = 0$ حلاً: $\|X^\top r\|_\infty \le \lambda$.

٢. ناظم الأعمدة: $\|x_1\|_2 = \sqrt{1.44 + 0.36 + 0.09} = \sqrt{1.89} = 1.3748$؛ $\|x_2\|_2 = \sqrt{2.56 + 1.44 + 0.64} = \sqrt{4.64} = 2.1541$؛ $\|x_3\|_2 = \sqrt{0.25 + 0.16 + 0.36} = \sqrt{0.77} = 0.8775$.

٣. $\|r\|_2 = \sqrt{0.25 + 0.09 + 0.04} = \sqrt{0.38} = 0.6164$.

٤. ب كوشي–شفارتس لكل عمود: $|x_j^\top r| \le \|x_j\|_2\|r\|_2$، فأعلى سقف ممكن $= 2.1541 \times 0.6164 = 1.3274$.

٥. بما أن $\lambda = 1.5 > 1.3274$، فـ $\|X^\top r\|_\infty \le 1.3274 < 1.5$ **مضمون قبل أي حساب للضروب الداخلية** $\Longrightarrow$ الحل هو $w = 0$.

٦. تحقّق مباشر: $x_1^\top r = 0.6 + 0.18 + 0.06 = 0.84$؛ $x_2^\top r = 0.8 - 0.36 + 0.16 = 0.60$؛ $x_3^\top r = 0.25 + 0.12 + 0.12 = 0.49$؛ فـ $\|X^\top r\|_\infty = 0.84 \le 1.3274 \le 1.5$. ✓

النتيجة: الحل هو الصفر، وتم إثبات ذلك بحدّ ناظمي رخيص (ثلاثة ناظمات أعمدة وناظم متبقٍّ) بدلاً من تشغيل محلّل كامل.
الربط بالذكاء الاصطناعي: هذه هي فكرة **الفحص الآمن** (safe screening / SAFE rules) في المسائل المتناثرة: نستخدم متراجحة الناظم الثنوي لنتخلّص من أعمدة أو من المسألة كلها قبل بدء التحسين. في مسائل بآلاف الميزات و«مسار تنظيم» (regularization path) كامل، يوفّر هذا أضعافاً مضاعفة من الوقت — والضمانة رياضية صارمة، لا تجريبية.

مثال (5.2-13): الناظم الثنوي للناظم المختلط $\ell_{2,1}$ (Group Lasso)

المعطيات: متجه أوزان $w \in \mathbb{R}^6$ مقسّم إلى ثلاث مجموعات من إحداثيين: $g_1 = (3, -4)$، $g_2 = (1, 1)$، $g_3 = (0, -2)$.

المطلوب: احسب $\|w\|_{2,1}$ و $\|w\|_{2,\infty}$، وتحقّق من الازدواج $(\ell_{2,1})^* = \ell_{2,\infty}$ عملياً.

الحل:

١. التعريف: $\|w\|_{2,1} = \sum_g \|w_g\|_2$ (ناظم ℓ_1 على ناظمات ℓ_2 للمجموعات)؛ و $\|w\|_{2,\infty} = \max_g \|w_g\|_2$.

٢. ناظمات المجموعات: $\|g_1\|_2 = \sqrt{9+16} = 5$؛ $\|g_2\|_2 = \sqrt{1+1} = 1.4142$؛ $\|g_3\|_2 = \sqrt{0+4} = 2$.

٣. $\|w\|_{2,1} = 5 + 1.4142 + 2 = 8.4142$؛ و $\|w\|_{2,\infty} = 5$.

٤. المتراجحة المعمّمة: $\langle w, w\rangle = \|w\|_2^2 = 25 + 2 + 4 = 31 \le \|w\|_{2,1}\,\|w\|_{2,\infty} = 8.4142 \times 5 = 42.07$ ✓.

٥. متجه الاختبار المُحقّق للتساوي: $z_g = w_g / \|w_g\|_2$ لكل مجموعة، أي $z = \big(0.6,\ -0.8,\ 0.7071,\ 0.7071,\ 0,\ -1\big)^\top$. عندها $\|z\|_{2,\infty} = \max(1,1,1) = 1$ ✓ و $\langle z, w\rangle = 5 + 1.4142 + 2 = 8.4142 = \|w\|_{2,1}$ ✓.

النتيجة: $(\ell_{2,1})^* = \ell_{2,\infty}$ مؤكَّد رقمياً: السقف 42.07 والقيمة المُعظَّمة 8.4142 مع $\|z\|_{2,\infty} = 1$.

الربط بالذكاء الاصطناعي: تنظيم Group-Lasso $(\ell_{2,1})$ هو الذي يختار **مجموعات كاملة من الميزات** (مثل قنوات الالتفاف، أو مجموعات المتغيّرات الوهمية لمتغيّر فئوي) لا إحداثيات مفردة. معرفة ثنويه ضرورية لاشتقاق شرط KKT وخوارزميات الإحداثيات النزولية ولحدود التعميم. القاعدة العامة: **ثنوي ناظم «مجموع على مجموعات من ناظم داخلي» هو «أقصى على مجموعات من الثنوي الداخلي».**

مثال (5.2-14): هولدر في فضاء الاحتمالات — تقدير خارج السياسة (off-policy) بنسب الأهمية

المعطيات: أربع عيّنات باحتمال متساوٍ $\frac{1}{4}$. نسب الأهمية $\rho = (1.5,\ 3.0,\ 0.2,\ 0.8)$ ومقادير الخسارة $|\ell| = (0.4,\ 1.2,\ 0.0,\ 2.1)$. استخدم $(p, q) = (3, \frac{3}{2})$.

المطلوب: احسب $\mathbb{E}|\rho\ell|$ فعلياً، وقارنه بسقف هولدر $\|\rho\|_3\,\|\ell\|_{3/2}$.

الحل:

١. الترافق: $\frac{1}{3} + \frac{1}{q} = 1 \Rightarrow q = \frac{3}{2}$ ✓.

٢. القيمة الفعلية: $\mathbb{E}|\rho\ell| = \frac{1}{4}\big(1.5\times0.4 + 3.0\times1.2 + 0.2\times0 + 0.8\times2.1\big) = \frac{1}{4}(0.6 + 3.6 + 0 + 1.68) = \frac{1}{4}(5.88) = 1.47$.

٣. $\|\rho\|_3 = \big(\mathbb{E}\rho^3\big)^{1/3} = \big[\frac{1}{4}(3.375 + 27 + 0.008 + 0.512)\big]^{1/3} = (7.7238)^{1/3} = 1.9766$.

٤. $\|\ell\|_{3/2}$: المقادير $|\ell|^{3/2} = (0.2530,\ 1.3145,\ 0,\ 3.0432)$، المتوسط $\mathbb{E}|\ell|^{3/2} = 1.1527$؛ إذن $\|\ell\|_{3/2} = \big(\mathbb{E}|\ell|^{3/2}\big)^{2/3} = (1.1527)^{2/3} = 1.0994$.

٥. سقف هولدر: $1.47 \geq 2.1731 = 1.0994 \times 1.9766$ ✓.

النتيجة: $\mathbb{E}|\rho\ell| = 1.47 \leq 2.1731$، والسقف صالح وإن كان فضفاضاً بمعامل ≈ 1.48.

الربط بالذكاء الاصطناعي: نسب الأهمية في تعلّم التعزيز خارج السياسة لها ذيول ثقيلة: قد لا يكون لـ ρ عزم ثانٍ، وقد لا تنطبق كوشي–شفارتس عملياً (الحدّ قد يكون لانهائياً). ميزة هولدر أنها **تتيح اختيار الأُسّ بحسب العزم الموجود فعلاً**: استخدم p أكبر إذا كان ذيل ρ ثقيلاً، عندئذ يقترب q من 1 ويخفّ العبء على ℓ. هذه هي الفكرة خلف مقاييس «وزنات الأهمية المقصوصة» و«مقدّرات العزم المُقصّ».

مثال (15-2.5): كشف انهيار التمثيل (representation collapse) من شرط التساوي في كوشي–شفارتس

المعطيات: ثلاثة متجهات خرج من طبقة تضمين مدمجة: $u = (1.5, -2.0, 0.5)^\top$، و $v = (-3.0, 4.0, -1.0)^\top$، و $w = (1.5, -2.0, 0.6)^\top$.

المطلوب: استخدم **فسحة** كوشي–شفارتس $\delta = \|x\|_2\|y\|_2 - |\langle x, y\rangle|$ كمؤشّر لانهيار التمثيل، وقيّم الأزواج الثلاثة.

الحل:

١. $\|u\|_2 = \sqrt{2.25 + 4 + 0.25} = \sqrt{6.5} = 2.5495$.

٢. الزوج (u, v): لاحظ $v = -2u$ تماماً، فـ $\|v\|_2 = 5.0990$ و $\langle u, v\rangle = -13.0$؛ والسقف $= 2.5495 \times 5.0990 = 13.0$. الفسحة $\delta = 13.0 - 13.0 = 0$ $\Longrightarrow$ **تساوي تام** $\Longrightarrow$ تبعية خطية $\Longrightarrow$ انهيار كامل. و $\cos\theta = -1$.

٣. الزوج (u, w): $\|w\|_2 = \sqrt{2.25 + 4 + 0.36} = \sqrt{6.61} = 2.5709$؛ $\langle u, w\rangle = 2.25 + 4 + 0.30 = 6.55$، السقف $= 2.5495 \times 2.5709 = 6.5545$. الفسحة $\delta = 6.5545 - 6.55 = 0.0045$، و $\cos\theta = 6.55/6.5545 = 0.99931$. مؤشّر الانهيار $1 - |\cos\theta| = 0.00069$ $\Longrightarrow$ **شبه انهيار**.

٤. الزوج (v, w): $\langle v, w\rangle = -4.5 - 8 - 0.6 = -13.1$؛ السقف $= 5.0990 \times 2.5709 = 13.109$؛ الفسحة $= 0.009$ $\Longrightarrow$ شبه انهيار أيضاً (متوقّع: كلاهما قريب من u).

النتيجة: الفسحة تعمل مؤشّراً حسّاساً: $\delta = 0$ للزوج المتوازي تماماً، و $\delta \approx 0.0045$ للزوج شبه المتوازي.

الربط بالذكاء الاصطناعي: في التعلّم المتناقض (contrastive learning) والتعلّم الذاتي الإشراف (SimCLR، BYOL، VICReg) أخطر وضع فشل هو **الانهيار** — كل التضمينات تصبح متوازية أو ثابتة. مؤشّر التشخيص المستعمل عملياً (مثل فقدان التباين في VICReg) هو في جوهره قياس **بُعد** المتجهات عن شرط التساوي في كوشي–شفارتس. القاعدة: راقب $\min_{i \neq j}(1 - |\cos\theta_{ij}|)$ عبر الدفعة؛ انحداره إلى الصفر يعني الانهيار.

4.2.5 أخطاء شائعة في تطبيق متراجحات كوشي–شفارتس وهولدر

الخطأ الشائع	لماذا هو خطأ؟	التصحيح
تطبيق $\|x\|_p = (\sum \|x_i\|^p)^{1/p}$ مع $p < 1$	متراجحة المثلث تفشل، فلا يوجد ناظم	اطلب $p \geq 1$ دائماً، و$p < 1$ يُستخدم كـ «بديل مقعّب» فقط
$\|\langle x, y\rangle\| \leq \|x\|_1 \|y$ أصحّ من كوشي–شفارتس	صحيح لكنه أضعف: $\|x\|_1 \geq \|x\|_2$	استخدم الناظمين **المترافقين**: ℓ_2 مع ℓ_2، أو ℓ_1 مع ℓ_∞
نسيان شرط التوافق $\frac{1}{p} + \frac{1}{q} = 1$	المتراجحة باطلة بلا هذا الشرط	احسب $q = p/(p-1)$ دائماً قبل الاستخدام
الخلط بين $\|\cdot\|_*$ والناظم الإقليدي	الثنوي يعتمد على الناظم الأصلي: $(\ell_1)^* = \ell_\infty$ لا ℓ_2	عيّن الناظم الأصلي أولاً، ثم ثنويه
$\|x + y\| \leq \|x$ لتقدير نمو الخطأ واعتباره محكماً	الحدّ فضفاض حين يكون المتجهان متعاكسين	احسب الزاوية؛ استخدم المتطابقة $\|x+y\|^2 = \|x\|^2 + \|y\|^2 + 2\langle x, y\rangle$
شي–شفارتس على مصفوفة النواة **كافٍ** لصلاحيتها	هو ضروري فقط	تحقّق من موجبية التحديد (Sylvester) أو القيم الذاتية
تجاهل شرط $x \neq 0$ عند حساب الزاوية	القسمة على $\|x\|_2 = 0$ غير معرّفة	تحقّق من $\|x\|_2 > \varepsilon$ قبل حساب arccos
قصّ التدرّج لكل دفعة فرعية بدل المجموع	يُغيّر الاتجاه ويقلّل الناظم دون داعٍ	اجمع أولاً، ثم اقصّ مرة واحدة
افتراض أن sup في تعريف الثنوي لا يُحقَّق	كرة الوحدة متراصّة والشكل خطّي $\Longrightarrow$ يتحقّق كـ max	استخدم $\max_{\|x\|=1}$ وابحث عن $x^\star$ صريحاً
$\|z\| \leq \|\langle z, x\rangle\|$ وبين $\|\langle z, x\rangle\| \leq \|z\| \|x\|_*$	النجمة على الناظم **الثنوي** فقط؛ الترتيب مهم لكنه متناظر هنا	اكتب: الناظم الثنوي يقابل الناظم الأصلي، ولا تضع النجمة على الاثنين

الفكرة في سطر: على فضاء **منتهي البعد**، كل النواظم متكافئة: لا يوجد ناظم «أصحّ» من آخر من حيث التقارب أو الاتصال أو الاستمرارية. لكن **ثوابت التحويل** بينها تعتمد على البعد n — وهذه الثوابت بالذات هي التي تصنع الفرق بين حدّ تعميم مفيد وحدّ تعميم فارغ. في الأبعاد اللانهائية (الدوال، الشبكات العصبية كعناصر في فضاء دالي) **يفشل** التكافؤ، وهناك تكمن معظم صعوبات النظرية.

1.3.5 الصياغة الرسمية

نظرية (رتابة نواظم ℓ_p وحدود التحويل بينها).

ليكن $x \in \mathbb{R}^n$ و $1 \leq p \leq q \leq \infty$. عندئذٍ:

$$\|x\|_q \;\leq\; \|x\|_p \;\leq\; n^{\frac{1}{p}-\frac{1}{q}}\, \|x\|_q \tag{13.5}$$

والحدّان **محكمان** (لا يمكن تحسينهما): الأسفل يتحقّق للمتجهات وحيدة الإحداثي $x = e_i$، والأعلى للمتجهات متساوية الإحداثيات $x = \mathbf{1}$.

جدول رموز (13.5):

الرمز	المعنى	ملاحظات
p	الأُسّ الأصغر	$1 \leq p \leq q$
q	الأُسّ الأكبر	قد يكون ∞
$\|x\|_q$	الناظم بالأُسّ الأكبر	**أصغر** قيمة: الطرف الأيسر
$\|x\|_p$	الناظم بالأُسّ الأصغر	أكبر قيمة
n	بُعد الفضاء	مصدر اعتماد الثابت على البعد
$n^{1/p-1/q}$	ثابت التحويل العلوي	$\sqrt{n}$: $p=2, q=\infty$؛ $\sqrt{n}$: $p=1, q=2$؛ n: $p=1, q=\infty$
e_i	متجه الوحدة في الإحداثي i	يجعل الحدّ الأسفل مُحكَماً: كل النواظم $= 1$
$\mathbf{1}$	متجه كل إحداثياته 1	يجعل الحدّ الأعلى مُحكَماً: $\|\mathbf{1}\|_p = n^{1/p}$
«محكم» (sharp) / tight)	الثابت لا يمكن تصغيره	يثبت أن الاعتماد على n حقيقي لا صناعي

نظرية (التكافؤ العام).

ليكن $\|\cdot\|_\alpha$ و $\|\cdot\|_\beta$ ناظمين أيّين على فضاء متجهي منتهي البعد V ببعد n. عندئذٍ يوجد ثابتان $c, C > 0$ بحيث لكل $x \in V$:

$$c\,\|x\|_\alpha \;\le\; \|x\|_\beta \;\le\; C\,\|x\|_\alpha \tag{14.5}$$

وأفضل (أصغر) ثابت أعلى وأكبر ثابت أسفل هما:

$$C_{\alpha\to\beta} \;=\; \max_{\|x\|_\alpha=1} \|x\|_\beta, \qquad c_{\alpha\to\beta} \;=\; \min_{\|x\|_\alpha=1} \|x\|_\beta \;=\; \frac{1}{C_{\beta\to\alpha}} \tag{15.5}$$

جدول رموز (14.5)–(15.5):

الرمز	المعنى	ملاحظات
$\|\cdot\|_\alpha,\ \|\cdot\|_\beta$	ناظمان أيّان على V	قد يكونان ℓ_q/ℓ_p، أو ناظمين مصفوفيّين، أو ناظمين «مركّبين»
c	ثابت التحويل السفلي (أكبر قيمة ممكنة له)	$c > 0$ دائماً في الأبعاد المنتهية
C	ثابت التحويل العلوي (أصغر قيمة ممكنة له)	$C < \infty$ دائماً في الأبعاد المنتهية
V	فضاء متجهي **منتهي البعد**	الشرط جوهري: في الأبعاد اللانهائية يفشل التكافؤ
$n = \dim V$	بُعد الفضاء	يظهر في c و C الفعليين
$\max_{\|x\|_\alpha=1}$	التعظيم على **سطح** كرة الوحدة الأولى	يعطي «أقصى تمدّد» للناظم الثاني
$\min_{\|x\|_\alpha=1}$	التصغير على السطح نفسه	يعطي «أدنى تمدّد»
$C_{\alpha\to\beta}$	الثابت الأمثل للاتجاه $\alpha \to \beta$	الرمز ذو السهم يوضّح الاتجاه
$1/C_{\beta\to\alpha}$	العلاقة الانعكاسية بين الثابتين	توفّر حسابَ نصفِ الثوابت

مسلّمة التراصّ (حجر أساس البرهان):

$$S_\alpha \;=\; \{\, x \in V : \|x\|_\alpha = 1 \,\} \text{ (compact) متراصّة}, \qquad x \mapsto \|x\|_\beta \text{ متصلة وموجبة تماماً على } S_\alpha \tag{16.5}$$

نتيجة (التنقية بالتناثر — sparse refinement). ليكن x متناثراً بـ s إحداثي غير صفري ($|\operatorname{supp}(x)| \;=\; s$)، و $1 \le q \le p$. عندئذٍ الوعاء الفعّال للبعد هو s لا n:

$$\|x\|_1 \;\le\; \sqrt{s}\,\|x\|_2 \qquad \text{وخاصةً} \qquad \|x\|_p \;\le\; s^{\frac{1}{q}-\frac{1}{p}}\,\|x\|_q, \tag{17.5}$$

جدول رموز (16.5)–(17.5):

الرمز	المعنى	ملاحظات
S_α	سطح كرة الوحدة للناظم α (وحدة الكرة)	مجموعة مغلقة ومحدودة في بعد منتهي $\Longrightarrow$ متراصّة (Heine–Borel)
«متراصّة»	كل متتالية فيها لها متتالية جزئية تقاربية	الضمانة وراء وجود min و max
«متصلة وموجبة تماماً»	$\|x\|_\beta > 0$ لكل $x \in S_\alpha$	تمنع أن يكون الأدنى صفراً
$\operatorname{supp}(x)$	دعم المتجه: مجموعة الإحداثيات غير الصفرية	$\{i : x_i \neq 0\}$
s	عدد الإحداثيات غير الصفرية (مستوى التناثر)	$s \le n$
$s^{1/q-1/p}$	ثابت التحويل **المعتمد على التناثر**	بديلٌ لـ $n^{1/q-1/p}$
$\sqrt{s}$	الحالة الخاصة $p = 1, q = 2$	الثابت الشهير في تحليل الضغط المتناثر
$q \le p$	ترتيب الأُسّين في (17.5)	معكوس ترتيب (13.5) ظاهرياً بسبب صيغة الأُسّ

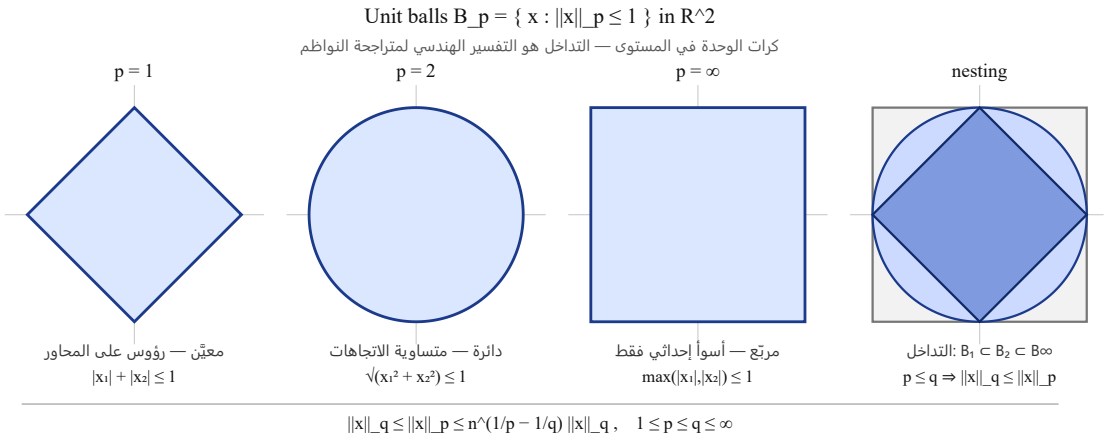
نتيجة (التحدّب وتمثيل دالة الدعم). كل ناظم دالةٌ **محدّبة**، وله تمثيل مزدوج:

$$\|\theta x + (1-\theta)y\| \;\le\; \theta\|x\| + (1-\theta)\|y\|, \quad \theta \in [0,1]; \qquad \|x\| \;=\; \max_{\|z\|_*\le 1} \langle z,\, x\rangle \tag{18.5}$$

جدول رموز (18.5):

الرمز	المعنى	ملاحظات
θ	معامل الخلط بين x و y	$\theta \in [0,1]$
$\theta x + (1-\theta)y$	النقطة على القطعة المستقيمة بينهما	—
المتراجحة اليسرى	تحدّب الناظم	يتبع من التجانس + متراجحة المثلث
$\max_{\|z\|_* \le 1}$	التعظيم على كرة الناظم **الثنوي**	—
$\langle z, x \rangle$	الشكل الخطي	—
المتطابقة اليمنى	كل ناظم = **دالة دعم** لكرته الثنوية	يربط الناظم بالهندسة المحدّبة وبالتنظيم
z	متجه الاختبار في الكرة الثنوية	عند $z = x/\|x\|_2$: $\|\cdot\|_2$

الشكل الهندسي للتكافؤ: تداخل كرات الوحدة — الكرة الأصغر أُسّاً داخل الكرة الأكبر أُسّاً، ونسبةُ التمدّد هي $n^{1/p-1/q}$:



شكل ٣.٥: *
كرات الوحدة لنواظم p وتداخلها

2.3.5 البرهان

برهان (13.5) — الحدّ الأسفل $\|x\|_q \le \|x\|_p$.

بلا فقدان العمومية نُطبّع بحيث $\|x\|_p = 1$ (التجانس يجعل ذلك مشروعاً). عندئذٍ $|x_i| \le 1$ لكل i، ومن ثم $|x_i|^q \le |x_i|^p$ لأن $q \ge p$. بالجمع:

$$\sum_i |x_i|^q \le \sum_i |x_i|^p = 1 \quad \Longrightarrow \quad \|x\|_q \le 1 = \|x\|_p$$

برهان (13.5) — الحدّ الأعلى $\|x\|_p \le n^{1/p-1/q}\|x\|_q$.

نُطبّق هولدر على المتجهين $(1,1,\dots,1)$ و $(|x_1|^p,\dots,|x_n|^p)$ بالأُسّين المترافقين $r = \frac{q}{p} \ge 1$ و $r' = \frac{q}{q-p}$:

$$\sum_i |x_i|^p \le \Big(\sum_i 1^{r'}\Big)^{1/r'} \Big(\sum_i |x_i|^{pr}\Big)^{1/r} = n^{\frac{q-p}{q}} \Big(\sum_i |x_i|^q\Big)^{\frac{p}{q}}$$

برفع الطرفين إلى الأُسّ $1/p$:

$$\|x\|_p \le n^{\frac{q-p}{pq}}\,\|x\|_q = n^{\frac{1}{p}-\frac{1}{q}}\,\|x\|_q \qquad \blacksquare$$

الإحكام: للمتجه $x=\mathbf{1}$: $\|\mathbf{1}\|_p = n^{1/p}$ و $\|\mathbf{1}\|_q = n^{1/q}$، فالنسبة $\|x\|_p/\|x\|_q = n^{1/p-1/q}$ — تبلغ الثابت تماماً. ولـ $x=e_i$: كل النواظم $=1$ فالنسبة $=1$ — تبلغ الثابت الأسفل. $\blacksquare$

برهان (14.5)-(16.5).

الدالة $\varphi(x)=\|x\|_\beta$ متصلة على V (لأن $|\varphi(x)-\varphi(y)| \le \|x-y\|_\beta \le C'\|x-y\|_\alpha$ باستخدام (13.5)) المُعمَّم أو مباشرةً من المتراجحة الفرقية). ومجموعة $S_\alpha=\{x:\|x\|_\alpha=1\}$ مغلقة ومحدودة في $V\cong\mathbb{R}^n$، فهي **متراصّة** بنظرية هاينه-بوريل. وعليه تُحقّق φ أدناها وأعلاها على S_α:

$$\exists\, x_{\min}, x_{\max} \in S_\alpha : \quad c=\varphi(x_{\min}) \le \|x\|_\beta \le \varphi(x_{\max}) = C$$

ولأن $\|x\|_\beta>0$ على S_α (إذ $x\neq 0$ هناك)، فإن $c>0$. وأخيراً، لكل $x\neq 0$ نُطبّق ذلك على $x/\|x\|_\alpha \in S_\alpha$ ونضرب بـ $\|x\|_\alpha$ فنحصل على (14.5). والعلاقة $c_{\alpha\to\beta}=1/C_{\beta\to\alpha}$ تتبع من قلب المتراجحة. $\blacksquare$

برهان (17.5).

ليكن $S=\operatorname{supp}(x)$ بـ $|S|=s$. بتطبيق (13.5) على المتجه المقيَّد x_S (وهو عنصر في $\mathbb{R}^s$) مع الأُسّين $q\le p$:

$$\|x\|_p = \|x_S\|_p \le s^{\frac{1}{q}-\frac{1}{p}}\|x_S\|_q = s^{\frac{1}{q}-\frac{1}{p}}\|x\|_q$$

وحالة $(q,p)=(2,1)$ تعطي $\|x\|_1 \le \sqrt{s}\,\|x\|_2$. بديل مباشر لها: كوشي-شفارتس على الدعم: $\sum_{i\in S}|x_i|\cdot 1 \le \sqrt{\sum_{i\in S}x_i^2}\,\sqrt{s}$. $\blacksquare$

برهان (18.5).

التحدّب: $\|\theta x+(1-\theta)y\| \le \|\theta x\|+\|(1-\theta)y\| = \theta\|x\|+(1-\theta)\|y\|$ من (N2)+(N3) مع $\theta, 1-\theta \ge 0$. وتمثيل دالة الدعم: من تعريف الثنوي $\|x\| \le \|x\|\|z\|_* \le \|x\|$ لكل $\|z\|_*\le 1$، فـ $\max \le \|x\|$؛ والعكس يتبع من (11.5)(د). $\blacksquare$

تنبيه جوهري: التكافؤ (14.5) يضمن أن **التقارب** لا يعتمد على الناظم: $x_k \to x$ بأحدها $\iff$ بأيّ آخر. لكن **سرعة** التقارب المعبَّر عنها بعدد الخطوات قد تتغيّر بثابت يعتمد على n. مثال: إن كان $\|e_k\|_2 \le \rho^k\|e_0\|_2$ فإن $\|e_k\|_1 \le \sqrt{n}\,\rho^k\|e_0\|_1$ — الرقم ρ نفسه لم يتغيّر، لكن الوصول إلى دقة مطلقة معيّنة يتطلّب $\frac{\log n}{2\log(1/\rho)}$ خطوة إضافية. هذا بالضبط هو «ثمن البعد».

3.3.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (3.5-1): تحويل بين ℓ_1 و ℓ_2 في بُعد $n = 1000$ — حدود تدرّج متوازٍ

المعطيات: تدرّج $g \in \mathbb{R}^{1000}$ ناظمه الإقليدي $\|g\|_2 = 0.35$.
المطلوب: حدود ℓ_1 الممكنة $\|g\|_1$، ومثالان يبلغان الحدّين.
الحل:

١. من (13.5) مع $(p, q) = (1, 2)$: $\|g\|_2 \le \|g\|_1 \le n^{1-1/2}\|g\|_2 = \sqrt{1000}\,\|g\|_2$.

٢. الحدّ الأسفل: $\|g\|_1 \ge 0.35$.

٣. الحدّ الأعلى: $\sqrt{1000} = 31.6228$، فـ $\|g\|_1 \le 31.6228 \times 0.35 = 11.068$.

٤. متجه يبلغ الأسفل: $g = 0.35\,e_1$ (إحداثي واحد فقط) $\Longrightarrow \|g\|_1 = \|g\|_2 = 0.35$ ✓.

٥. متجه يبلغ الأعلى: $g_i = 0.35/\sqrt{1000} = 0.011068$ لكل $i \Longrightarrow \|g\|_2 = \sqrt{1000 \times 0.011068^2} = 0.35$ و $\|g\|_1 = 1000 \times 0.011068 = 11.068$ ✓.

النتيجة: $\|g\|_1 \in [0.35,\ 11.068]$ — مجالٌ اتساعه **معامل** 31.6، ولا يمكن تضييقه بمعلومة $\|g\|_2$ وحدها.
الربط بالذكاء الاصطناعي: حين تقرأ في بحث أن «قصّ التدرّج عند ناظم 1.0» ثم تريد ترجمته إلى ميزانية ℓ_1 (كما في خوارزميات الضغط المتناثر k-top)، فهذه الفجوة بمعامل $\sqrt{n}$ هي بالضبط ما يجعل الترجمة خطرة. دوماً اذكر **أيّ** ناظم يقصد البحث؛ فالمعامل $\sqrt{1000} \approx 32$ ليس تفصيلاً.

مثال (3.5-2): اضطراب صورة $\ell_\infty = 8/255$ كم يبلغ ناظمه ℓ_2؟

المعطيات: صورة مُطبَّعة 28×28 $(n = 784)$ واضطراب خصمي بشرط $\|\delta\|_\infty \le \varepsilon = 8/255$.
المطلوب: أقصى $\|\delta\|_2$ ممكن، ومقارنته بناظم الصورة نفسها.
الحل:

١. $\varepsilon = 8/255 = 0.03137$.

٢. من (13.5) مع $(p, q) = (2, \infty)$: $\|\delta\|_\infty \le \|\delta\|_2 \le \sqrt{784}\,\|\delta\|_\infty$.

٣. الحدّ الأعلى: $\sqrt{784} = 28$، فـ $\|\delta\|_2 \le 28 \times 0.03137 = 0.8784$.

٤. الحدّ الأسفل: $\|\delta\|_2 \ge \|\delta\|_\infty = 0.03137$ (يتحقّق إذا كان الاضطراب في بكسل واحد).

٥. الإحكام: $\delta = \varepsilon\mathbf{1}$ (كل البكسلات مزاحة بالكامل) يعطي $\|\delta\|_2 = \sqrt{784 \times \varepsilon^2} = 0.8784$ ✓.

٦. المقارنة: صورة مُطبَّعة ناظمها $\|x\|_2 \approx 1$، فالاضطراب قد يبلغ 87.8% من ناظم الصورة — «غير مرئي» بالعين لكنه ضخم قياسياً.

النتيجة: $\|\delta\|_2 \in [0.03137,\ 0.8784]$ — أي حتى $0.88 \approx$ من ناظم الصورة كلها.

الربط بالذكاء الاصطناعي: هذا يحلّ اللغز الشهير: كيف يكون هجوم «غير محسوس» ($\varepsilon = 8/255$ لكل بكسل) قادراً على قلب تصنيف الشبكة؟ الجواب: لأن ميزانية ℓ_∞ الصغيرة تترجم إلى ميزانية ℓ_2 كبيرة بمعامل $\sqrt{n}$ — فالهجوم يوزّع «همسة» على كل بكسل فتجتمع 784 همسة في اتجاه واحد. أي دفاع يجب أن يقيس المتانة **بالناظم الصحيح للميزانية.**

مثال (3-3.5): التناثر يُصغّر ثابت التحويل من $\sqrt{d}$ إلى $\sqrt{s}$

المعطيات: تدرّج متناثر $g \in \mathbb{R}^{5000}$ ناظمه $\|g\|_2 = 6.4$، وعدد غير الصفري $s = 12$ (مثلاً بعد $k$top-sparsfiication).

المطلوب: قارن حدود $\|g\|_1$ بالثابت الكثيف $\sqrt{d}$ وبالثابت المتناثر $\sqrt{s}$.

الحل:

١. الحدّ الكثيف (يتجاهل التناثر): $\|g\|_1 \le \sqrt{5000} \times 6.4 = 70.711 \times 6.4 = 452.5$.

٢. الحدّ المتناثر (17.5): $\|g\|_1 \le \sqrt{12} \times 6.4 = 3.4641 \times 6.4 = 22.17$.

٣. نسبة التحسين: $\sqrt{5000/12} = \sqrt{416.7} = 20.41 = 452.5/22.17$ ✓.

٤. الحدّ الأسفل في الحالتين: $\|g\|_1 \ge \|g\|_2 = 6.4$ (يتحقّق إذا تركّز الناظم في إحداثي واحد).

٥. الإحكام: لو كانت الـ 12 قيم غير الصفرية متساوية المقدار $|g_i| = 6.4/\sqrt{12} = 1.8475$، لكان $\|g\|_1 = 12 \times 1.8475 = 22.17$ ✓.

النتيجة: $\|g\|_1 \in [6.4,\ 22.17]$ بدلاً من $[6.4,\ 452.5]$ — تحسين بمعامل 20.4.

الربط بالذكاء الاصطناعي: هذا هو المبرّر الرياضي الكامل لـ **ضغط التدرّجات المتناثر** في التدريب الموزّع ($k$top-sparsfiication، Deep Gradient Compression): الخطأ المُدخَل يُقاس بـ $\|g - g_s\|$، وحدوده تتقلّص مع $\sqrt{s}$ لا مع $\sqrt{d}$. كلما زاد التناثر تحسّنت الحدود، وإن ظلّ الناظم الإقليدي ثابتاً.

مثال (4-3.5): ثمن البعد — كم خطوة إضافية يكلّفها قياس الخطأ بـ ℓ_∞ بدل ℓ_2؟

المعطيات: خوارزمية تكرارية تتقارب خطياً: $\|e_k\|_2 \le \rho^k \|e_0\|_2$ بـ $\rho = 0.9$ و $n = 300$. المطلوب أن يصل الخطأ إلى $\tau = 10^{-3}$، والخطأ الابتدائي $\|e_0\|_\infty = 1$.

المطلوب: عدد التكرارات إن قِسنا الخطأ بـ ℓ_2، وإن قِسناه بـ ℓ_∞.

الحل:

١. التحويل الابتدائي: $\|e_0\|_2 \le \sqrt{n}\,\|e_0\|_\infty = \sqrt{300} = 17.3205$.

٢. قياس ℓ_2: نحتاج $\rho^k \le 0.001$، أي $k \ge \dfrac{\ln(10^{-3})}{\ln(0.9)} = \dfrac{-6.9078}{-0.10536} = 65.56 \Rightarrow k = 66$.

٣. قياس ℓ_∞: $\|e_k\|_\infty \le \|e_k\|_2 \le \rho^k \|e_0\|_2 \le \rho^k \sqrt{300}$. نحتاج $0.9^k \times 17.3205 \le 10^{-3}$، أي $0.9^k \le 5.7735 \times 10^{-5}$، فـ $k \ge \dfrac{\ln(5.7735 \times 10^{-5})}{\ln(0.9)} = \dfrac{-9.7582}{-0.10536} = 92.62 \Rightarrow k = 93$.

٤. الفرق: $93 - 66 = 27$ تكراراً إضافياً.

٥. الصيغة العامة للفرق: $\dfrac{\ln \sqrt{n}}{\ln(1/\rho)} = \dfrac{2.8519}{0.10536} = 27.07$ ✓.

النتيجة: معدّل التقارب $\rho = 0.9$ **لم يتغيّر**، الذي تغيّر هو الثابت، فأضاف 27 تكراراً (41% ≈ زيادة).
الربط بالذكاء الاصطناعي: هذه هي الدلالة الدقيقة لقولنا «التكافؤ لا يعني التساوي». في تقارير التدريب، الانتقال من معيار توقّف على $\|g\|_2$ إلى معيار على $\|g\|_\infty$ (أو على تغيّر الخسارة) يغيّر عدد الخطوات الملحوظة دون أن يغيّر الخوارزمية. وعند مقارنة طريقتين في بحث، يجب أن يُقاس الخطأ **بالناظم نفسه** وإلا كانت المقارنة مضلّلة بمعامل $\sqrt{n}$.

مثال (5-3.5): تحويل ثابت ليبشيتز من ℓ_2 إلى ℓ_∞ — والتحسين المتناثر

المعطيات: طبقة جاكوبيها J بشرط $\|J\|_2 \le L_2 = 2.5$، والمدخل صورة $n = 784$ بُعداً.
المطلوب: ثابت ليبشيتز بالناظمين: من $(\mathbb{R}^n, \ell_\infty)$ إلى $(\mathbb{R}, \ell_\infty)$ للحالة العامة، ولحالة اضطراب متناثر على $s = 20$ بكسلاً.
الحل:

١. تعريف ثابت ليبشيتز بالناظمين α (مدخل) و β (خرج): $\|J\delta\|_\beta \le L_{\alpha\to\beta} \|\delta\|_\alpha$.

٢. الحالة العامة $(\ell_\infty \to \ell_\infty)$: $\|J\delta\|_\infty \le \|J\delta\|_2 \le \|J\|_2 \|\delta\|_2 \le L_2 \sqrt{n}\, \|\delta\|_\infty$. إذن $L_{\infty\to\infty} \le 2.5 \times 28 = 70$.

٣. الحالة المتناثرة: من (17.5)، $\|J\delta\|_\infty \le \|\delta\|_2 \le \sqrt{s}\, \|\delta\|_\infty = \sqrt{20}\, \|\delta\|_\infty = 4.4721 \|\delta\|_\infty$. إذن $2.5 \times 4.4721 = 11.18$.

٤. نسبة التحسين: $70/11.18 = 6.26 = \sqrt{784/20} = \sqrt{39.2} = 6.26$ ✓.

النتيجة: $L_{\infty\to\infty} = 70$ للاضطراب العام، و 11.18 لاضطراب على 20 بكسلاً فقط — تحسين بمعامل 6.26.
الربط بالذكاء الاصطناعي: هذا هو جوهر **التحقّق الرسمي من المتانة** (certfiied robustness): كلّما استطعت تقييد «دعم» الاضطراب (عدد البكسلات أو الكلمات المعدَّلة)، تحسّن الحدّ المضمون بمعامل $\sqrt{s/n}$ بلا أي تغيير في النموذج. لهذا تُعدّ الهجمات «الموضعية» (لصقة صغيرة، تعديل كلمات قليلة) أصعب إثباتاً للأمان من الهجمات الشاملة، ولهذا تُقاس المتانة دائماً **مقرونة بميزانية وموضع**.

مثال (6-3.5): بين الناظم الطيفي والناظم الفروبنيوسي لمصفوفة أوزان 768×1024

المعطيات: مصفوفة أوزان $W \in \mathbb{R}^{1024\times 768}$، ناظمها الطيفي $\|W\|_2 = \sigma_1 = 3.2$.
المطلوب: حدود $\|W\|_F$ الممكنة، والحالتان اللتان تبلغان الحدّين.
الحل:

١. العلاقة: $\|W\|_F^2 = \sum_{i=1}^{r} \sigma_i^2 \le r\,\sigma_1^2$ حيث $r = \text{rank}(W) \le \min(1024, 768) = 768$.

٢. الحدّ الأعلى: $\|W\|_F \le \sqrt{768} \times 3.2 = 27.7128 \times 3.2 = 88.68$.

٣. الحدّ الأسفل: $\|W\|_F \ge \sigma_1 = 3.2$.

٤. الحالة المُحقِّقة للأسفل: $\text{rank}(W) = 1$ (كل القيم المفردة الأخرى صفر) $\Longrightarrow \|W\|_F = 3.2$ ✓.

٥. الحالة المُحقِّقة للأعلى: كل القيم المفردة الـ 768 متساوية $3.2 \Longrightarrow \|W\|_F = \sqrt{768 \times 10.24} = 88.68$ ✓.

النتيجة: $3.2 \le \|W\|_F \le 88.68$.
الربط بالذكاء الاصطناعي: كثير من بحوث تنظيم الأوزان تستخدم $\|W\|_F$ (تنظيم «weight decay») لكن التحليل النظري يستخدم $\|W\|_2$ (لأنه ثابت ليبشيتز). التحويل بينهما يكلّف معاملاً حتى ≈ 27.7 $\sqrt{\min(m,n)}$. ولهذا ظهرت تقنيات **التطبيع الطيفي** (spectral normalization) التي تقترب من $\|W\|_2$ مباشرة: فهي تضبط الكمية التي تتحكّم فعلاً باستقرار الشبكة، لا بديلاً عنها بفجوة $\sqrt{\text{width}}$.

مثال (5.3-7): لماذا يجب إعادة ضبط معامل التنظيم عند تغيير عرض الشبكة؟

المعطيات: نموذجان خطيان متشابهان: A بـ $n_A = 1000$ معلمة وناظم $\|w_A\|_1 = 5$؛ و B بـ $n_B = 4000$ معلمة وناظم $\|w_B\|_1 = 5$.
المطلوب: قارن $\|w\|_2$ المُضمَّن في كل نموذج، واستنتج كيف يجب أن يتغيّر معامل تنظيم ℓ_2 عند مضاعفة العرض.
الحل:

١. من (5.13): $\frac{\|w\|_1}{\sqrt{n}} \le \|w\|_2 \le \|w\|_1$.

٢. النموذج A: $\|w_A\|_2 \in [5/\sqrt{1000},\ 5] = [0.1581,\ 5]$.

٣. النموذج B: $\|w_B\|_2 \in [5/\sqrt{4000},\ 5] = [0.0791,\ 5]$.

٤. بافتراض الحالة «النموذجية» (المعاملات متقاربة المقدار، فتكون القيمة قرب الحدّ الأسفل): $\|w_A\|_2 \approx 0.1581$ و $\|w_B\|_2 \approx 0.0791$؛ والنسبة $0.1581/0.0791 = 2 = \sqrt{4000/1000}$ ✓.

٥. أثر ذلك على الجزاء: $\lambda\|w\|_2^2$ يصبح $\lambda \times 0.025$ لـ A مقابل $\lambda \times 0.00626$ لـ B — أي أن الجزاء الفعلي على B أضعف بـ 4 أضعاف $= n_B/n_A$.

٦. التصحيح: للحفاظ على القوّة نفسها يجب أن يُضبط λ مع n: $\lambda \propto n$ (أو ما يكافئه: تقسيم الجزاء على البعد، كما في تطبيع «fan-in»).

النتيجة: مضاعفة العرض $\times 4$ مع إبقاء $\|w\|_1$ و λ ثابتين يُضعف الجزاء الفعلي ℓ_2 بمعامل 4.

الربط بالذكاء الاصطناعي: هذا يفسّر ظاهرة عملية معروفة: نقل معامل decay weight بين نماذج مختلفة العرض (أو بين نموذج ومكمّله المضغوط) يغيّر سلوك التدريب. الحدود النظرية (13.5) تعطي المعامل الصحيح للتصحيح: λ يجب أن يتناسب مع البعد عند تثبيت الناظم ℓ_1، ومع $\sqrt{\text{width}}$ في حالات أخرى. القاعدة العملية: **عيّن التنظيم بوصفه «ناظماً مستهدفاً» لا «رقماً سحرياً».**

مثال (3.5-8): اختيار مقياس المسافة في فهرس البحث المتجهي (ANN)

المعطيات: تضمينات بُعد $d = 768$ في قاعدة بيانات متجهية. نعلم أن $\|x - y\|_2 = 0.6$ لزوج معيّن.

المطلوب: حدود ℓ_1 الموافقة؛ ثم عكس المسألة: إن كان عتبة الاسترجاع بالـ ℓ_1 هي 12، فما المرافق لها بـ ℓ_2؟

الحل:

١. الاتجاه الأول: $\|x-y\|_1 \le \sqrt{768}\,\|x-y\|_2 = 27.7128 \times 0.6 = 16.63$. ف $\|x-y\|_2 \le \|x-y\|_1$. $\|x-y\|_1 \in [0.6,\ 16.63]$.

٢. الاتجاه الثاني: $\frac{\|x-y\|_1}{\sqrt{768}} \le \|x-y\|_2 \le \|x-y\|_1$، أي $\|x-y\|_2 \in \left[\frac{12}{27.7128},\ 12\right] = [0.4330,\ 12]$.

٣. الفجوة في الحالتين بمعامل $\sqrt{768} = 27.7$ — لا يمكن تجاوزها بلا معلومة إضافية عن توزيع الفروق.

النتيجة: عتبة $\ell_1 = 12$ تقابل مجالاً كاملاً $[0.433,\ 12]$ من مسافات ℓ_2 — فالعتبتان **غير قابلتين للترجمة** بعامل ثابت.

الربط بالذكاء الاصطناعي: محرّكات البحث المتجهي (FAISS، HNSW، ScaNN) تبني فهارسها على مقياس واحد. الانتقال من ℓ_2 (أو الجداء الداخلي) إلى ℓ_1 يبدو تغييراً بسيطاً، لكن حدود التحويل بمعامل $\sqrt{d} = 27.7$ تعني أن **كل عتبة وكل معلمة فهرس يجب إعادة ضبطها.** ولهذا يشيع استخدام المسافة الإقليدية أو الجداء الداخلي: فهما ثابتان دورانياً، في حين أن ℓ_1 يعتمد على محاور الإحداثيات — وهو ما يجعله حسّاساً لتدوير الفضاء (مثل بعد PCA أو بعد طبقة تكييف).

مثال (3.5-9): ثوابت التكافؤ بين مسافة مالانوبيس والمسافة الإقليدية

المعطيات: مصفوفة تغاير $\Sigma = \text{diag}(4,\ 1,\ 0.25)$ لثلاث ميزات، ومسافة مالانوبيس $d_\Sigma(x,y) = \sqrt{(x-y)^\top \Sigma^{-1}(x-y)}$.

المطلوب: ثابتا التكافؤ مع المسافة الإقليدية، وتحقّق رقمي على متجه، وأثر ذلك على عتبة كشف الشذوذ.

الحل:

١. $\Sigma^{-1} = \text{diag}(0.25,\ 1,\ 4)$. قيمها الذاتية $(0.25,\ 1,\ 4)$.

٢. من (6.5) مع $G = \Sigma^{-1}$: $\sqrt{\lambda_{\min}(G)}\,\|z\|_2 \le \|z\|_G \le \sqrt{\lambda_{\max}(G)}\,\|z\|_2$، أي $0.5\|z\|_2 \le \|z\|_G \le 2\|z\|_2$.

٣. نسبة التمدّد: $C/c = 2/0.5 = 4 = \sqrt{\kappa(\Sigma)}$ حيث $\kappa(\Sigma) = 4/0.25 = 16$ ✓.

٤. تحقّق رقمي على $z = (0.5,\ 1.2,\ -0.3)^\top$: $\|z\|_2 = \sqrt{0.25 + 1.44 + 0.09} = \sqrt{1.78} = 1.3342$؛ و $z^\top \Sigma^{-1} z = 0.25 \times 0.25 + 1 \times 1.44 + 4 \times 0.09 = 0.0625 + 1.44 + 0.36 = 1.8625$؛ فـ $\|z\|_G = \sqrt{1.8625} = 1.3647$.

٥. التحقّق: $0.5 \times 1.3342 = 0.6671 \le 1.3647 \le 2 \times 1.3342 = 2.6684$ ✓.

النتيجة: المسافتان متكافئتان بثابتين $(0.5,\ 2)$؛ فأي عتبة إقليدية تُترجم إلى عتبة مالانوبيس بعامل غير محدّد في المدى $[0.5,\ 2]$.

الربط بالذكاء الاصطناعي: مسافة مالانوبيس هي المعيار في كشف الشذوذ متعدّد المتغيّرات وفي تعلّم المسافة. حدود التكافؤ تخبرنا بأمرين: (أ) **الترتيب** بين النقاط قد يتغيّر فعلاً عند الانتقال بين المسافتين (الفجوة بمعامل 4 هنا)، فلا يجوز افتراض تطابق النتائج؛ (ب) متى كانت $\kappa(\Sigma)$ كبيرة — أي ميزات مترابطة بقوة أو ذات تباينات متباينة جداً — اتّسعت الفجوة، وهذا بالضبط ما يجعل تبييض البيانات (whitening) خطوةً مسبقة ضرورية قبل NNk أو التجميع.

مثال (10-3.5): ميزانية القصّ ℓ_2 مقابل ℓ_∞ في نموذج بـ 10^6 معلمة

المعطيات: نموذج بـ $d = 10^6$ معلمة. خياران للقصّ: (أ) $\|g\|_2 \le 1.0$؛ (ب) $\|g\|_\infty \le 0.01$.

المطلوب: كم يبلغ الآخر في كل خيار؟ وأيّ الخيارين أشدّ؟

الحل:

١. من (أ) إلى (ب): $\|g\|_\infty \le \|g\|_2 \le 1.0$. فكل إحداثي مضمونٌ $|g_i| \le 1.0$ — وهو حدّ فضفاض جداً. ولو كان التحديث موزّعاً بالتساوي: $|g_i| = 1.0/\sqrt{10^6} = 10^{-3}$.

٢. من (ب) إلى (أ): $\|g\|_2 \le \sqrt{d}\,\|g\|_\infty = 1000 \times 0.01 = 10.0$. فالميزانية الإقليدية قد تصل إلى 10.0.

٣. المقارنة: الخيار (ب) يسمح بتحديث إقليدي أكبر بـ 10 أضعاف من الخيار (أ) (في أسوأ توزيع)، والفجوة بينهما معامل $\sqrt{d} = 1000$ في الاتجاه المعاكس.

٤. الخياران **غير قابلين للترجمة**، ولا يوجد أحدهما «أقوى» بإطلاق: (أ) يقيد الطول الكلي، (ب) يقيد أقصى إحداثي.

النتيجة: قصّ ℓ_2 عند 1.0 يقابله قصّ ℓ_∞ عند أي قيمة في $[10^{-3},\ 1.0]$ بحسب توزيع التحديث.

الربط بالذكاء الاصطناعي: هذا مثال حاسم على أن «مقدار القصّ» ليس رقماً كونياً. في النماذج الضخمة $(d \sim 10^9)$، الفجوة $\sqrt{d}$ تبلغ $31623 \approx$ — فذكر «قمنا بقصّ التدرّجات عند 1.0» بلا تحديد الناظم لا يعني شيئاً قابلاً للتكرار. كذلك «التنعيم التفاضلي الخصوصي» (DP-SGD) يعمل صراحةً بميزانية ℓ_2 لأن تحليل الخصوصية مبنيّ على حساسية ℓ_2 — وتحويلها إلى ℓ_∞ يفقد المعامل $\sqrt{d}$ كاملاً.

مثال (11-3.5): إحكام حدود التحويل — ثلاثة متجهات تبلغ ثلاثة حدود

المعطيات: $n = 64$. ثلاثة متجهات: $a = \mathbf{1}$ (كل إحداثياته 1)، و $b = e_1$، و c متناثر بـ $s = 4$ إحداثيات قيمتها 1 والباقي صفر.

المطلوب: تحقّق أن كل متجه يبلغ حدّاً مختلفاً من حدود (13.5) و (17.5).

الحل:

١. $a = \mathbf{1}$: $\|a\|_1 = 64$، $\|a\|_2 = \sqrt{64} = 8$، $\|a\|_\infty = 1$.

- $\|a\|_1/\|a\|_2 = 64/8 = 8 = \sqrt{64} \implies$ **يبلغ الحدّ الأعلى** لـ $(p,q) = (1,2)$ ✓
- $\|a\|_2/\|a\|_\infty = 8/1 = 8 = \sqrt{64} \implies$ **يبلغ الحدّ الأعلى** لـ $(p,q) = (2,\infty)$ ✓

١. $b = e_1$: $\|b\|_1 = \|b\|_2 = \|b\|_\infty = 1$. كل النسب $= 1 \implies$ **يبلغ الحدّ الأسفل** في الحالتين ✓.

٢. c $(s = 4)$: $\|c\|_1 = 4$، $\|c\|_2 = 2$، $\|c\|_\infty = 1$.

- $\|c\|_1/\|c\|_2 = 2 = \sqrt{4} = \sqrt{s} \implies$ **يبلغ حدّ (17.5) المتناثر** ✓، في حين أن الحدّ الكثيف $\sqrt{64} = 8$ فضفاض بمعامل 4.

النتيجة: الحدود في (13.5) و (17.5) **محكمة** — لا يمكن تحسين أيٍّ منها، وبيان ذلك هذه المتجهات الثلاثة.

الربط بالذكاء الاصطناعي: اختبار الإحكام ليس ترفاً نظرياً: حين تُثبَت أن حدّاً ما محكَم، تعرف أن تحسينه يحتاج **معلومة إضافية** (تناثر، بنية كتلية، انخفاض رتبة) لا تحسيناً في التحليل. وهذا بالضبط ما يوجّه البحث: كل تحسين في حدود التعميم جاء من إدخال معلومة بنيوية جديدة لا من شحذ المتراجحة.

مثال (12-3.5): تقرير خطأ المُحلّل التكراري بأيّ ناظم؟

المعطيات: متجه خطأ $e = (0.012,\ -0.008,\ 0.010,\ -0.010)^\top$ على $\mathbb{R}^4$.

المطلوب: النواظم الثلاثة للخطأ، وأثر اختيار الناظم على «الرقم المُعلَن».

الحل:

١. $\|e\|_1 = 0.012 + 0.008 + 0.010 + 0.010 = 0.040$.

٢. $\|e\|_2 = \sqrt{0.000144 + 0.000064 + 0.0001 + 0.0001} = \sqrt{0.000408} = 0.020199$.

٣. $\|e\|_\infty = 0.012$.

٤. التحقّق من (13.5): $0.040 \le 0.020199 \le 0.012$ ✓، والحدّ الأعلى $\sqrt{4} \times 0.012 = 0.024 \ge 0.020199$ ✓.

٥. الإحكام هنا: $\|e\|_1 = 0.040$ قريب من الحدّ الأعلى $2 \times 0.020199 = 0.040398$ لأن الإحداثيات متقاربة المقدار.

٦. الأثر على التقرير: الرقم نفسه يتراوح من 0.012 إلى 0.040 بحسب الناظم — أي بمعامل 3.33.

النتيجة: «الخطأ 0.012 =» (بـ ℓ_∞) و «الخطأ 0.040 =» (بـ ℓ_1) يصفان **الحل نفسه**، والفرق معامل 3.33.

الربط بالذكاء الاصطناعي: عند قراءة جداول دقّة المُحلّلات العددية أو تقارير تقارب التدريب، الناظم جزءٌ من القياس لا تفصيلٌ هامشي. الممارسة السليمة: الإعلان عن الناظم صراحةً، ويفضّل الإعلان عن $\|e\|_2/\|e_0\|_2$ (نسبة لا dimension-dependent بقدر أقل) مع ذكر معيار التوقّف. سنعود إلى هذا في الفصل السادس (التحليل العددي والاستقرار).

مثال (3.5-13): خطأ التكميم — الحدّ الأسوأ مقابل السلوك النموذجي

المعطيات: مصفوفة أوزان $W \in \mathbb{R}^{512\times 512}$ مُكمَّمة بخطوة $\Delta = 2^{-7} = 0.0078125$ (تكميم منتظم)، فخطأ كل إحداثي $\le \Delta/2$.

المطلوب: حدّ أسوأ حالة على $\|\Delta W\|_2$ باستخدام التكافؤ، ومقارنته بالقيمة النموذجية لخطأ التقريب.

الحل:

١. خطأ الإحداثي: $|\Delta W_{ij}| \le \Delta/2 = 0.00390625$.

٢. الحدّ بـ ℓ_∞: $\|\Delta W\|_\infty$ (كناظم أقصى إحداثي) ≤ 0.00390625.

٣. التحويل إلى الطيفي عبر الفروبنيوسي: $\|\Delta W\|_2 \le \|\Delta W\|_F = \sqrt{\sum_{ij}\Delta W_{ij}^2} \le \sqrt{mn}\,(\Delta/2) = 512 \times 0.00390625 = 2.0$.

٤. القيمة النموذجية (خطأ تقريب شبيه بالعشوائي، توزيع منتظم على $[-\Delta/2, \Delta/2]$): الانحراف المعياري للإحداثي $\sigma = \dfrac{\Delta}{2\sqrt{3}} = \dfrac{0.0078125}{3.4641} = 0.0022555$؛ وبتركيز ناظم المصفوفة العشوائية (§6.5): $\|\Delta W\|_2 \approx \sigma(\sqrt{m}+\sqrt{n}) = 0.0022555 \times (22.627 + 22.627) = 0.1021$.

٥. المقارنة: أسوأ حالة 2.0 مقابل نموذجي 0.1021 — فجوة بمعامل ≈ 19.6.

النتيجة: حدّ التكافؤ الأسوأ (2.0) صحيح لكنه متشائم جداً، والقيمة المرجوّة ≈ 0.10.

الربط بالذكاء الاصطناعي: هذه الفجوة بمعامل ≈ 20 هي السبب المباشر لوجود قسم كامل عن **تركيز النواظم** (§6.5): حدود أسوأ حالة مبنية على التكافؤ Deterministic تكون فارغة من المعنى في الأبعاد العالية، لأنها تفترض أن كل الإحداثيات تتآمر في الاتجاه الأسوأ. التكميم بعد التدريب (PTQ) يعتمد في الواقع على أن خطأ التقريب **شبيه بالعشوائي**، فتُستخدم حدود احتمالية لا حدود أسوأ حالة. وسنرى أن الفجوة تتّسع مع $\sqrt{mn}$ مقابل $\sqrt{m}+\sqrt{n}$.

مثال (3.5-14): لماذا يُنتج ℓ_1 حلولاً متناثرة؟ — المقارنة الهندسية الكاملة

المعطيات: قيد خطي $\langle w, a\rangle = 1$ مع $a = (1,1)^\top$. المطلوب تصغير ثلاثة نواظم مختلفة لـ $w = (t,\, 1-t)^\top$.

المطلوب: الحل الأمثل وقيمة الناظم في كل حالة، والاستنتاج الهندسي.

الحل:

١. كل الحلول الممكنة هي $w(t) = (t,\ 1-t)$ مع $t \in \mathbb{R}$.

٢. **تصغير** $\|w\|_1$: $|t| + |1-t|$. على المدى $t \in [0,1]$ القيمة $= t + 1 - t = 1$؛ وخارجه > 1. إذن القيمة الدنيا 1 **تُحقَّق على قطعة كاملة** $t \in [0,1]$، ومنها الركنان $(1,0)$ و $(0,1)$ — **حلول متناثرة**.

٣. **تصغير** $\|w\|_2$: $\sqrt{t^2 + (1-t)^2}$؛ المشتقّة تعطي $2t - 2(1-t) = 0 \Rightarrow t = \frac{1}{2}$. القيمة $= \sqrt{0.25 + 0.25} = 0.7071$ — **حل وحيد** غير متناثر.

٤. **تصغير** $\|w\|_\infty$: $\max(|t|, |1-t|)$؛ يُصغَّر عند $t = \frac{1}{2}$ بالقيمة 0.5 — **حل وحيد**.

٥. الترتيب: $1 \le 0.7071 \le 0.5$ ✓ مطابق لـ $\|w\|_\infty \le \|w\|_2 \le \|w\|_1$.

النتيجة: ℓ_1 يعطي **أكبر** قيمة دنيا للناظم (1 مقابل 0.7071 و 0.5) — ومع ذلك هو الذي يُنتج التناثر، لأنه يعطي **مجموعة حلول** تتضمّن أركاناً على المحاور، في حين أن ℓ_2 و ℓ_∞ يعطيان حلولاً وحيدة داخلية.

الربط بالذكاء الاصطناعي: التناثر ليس «لأن ℓ_1 أصغر»، بل لأن **كرة** ℓ_1 **لها أركان حادّة على محاور الإحداثيات**: حين تتمدّد كرة الوحدة حتّى تلامس مستوى القيد، فأرجح نقطة تلامس هي ركنٌ يقع على محور — أي أن بعض الإحداثيات تصفر تماماً. كرة ℓ_2 ملساء فنقطة التماس عامّة الموضع. هذا هو التفسير الهندسي الكامل لـ Lasso وتقليم الأوزان وضغط النماذج المتناثر (sparse pruning)، وهو ما لا تستطيع حدود التكافؤ وحدها تفسيره: فالتكافؤ يتحدّث عن **المقادير**، والتناثر يتحدّث عن **الشكل**.

مثال (3.5-15): لا ناظم «أفضل دائماً» — الحدود تقيس جداءً لا ناظماً مفرداً

المعطيات: حدّ تعميم من نمط راديماخر لمصنّف خطي: excess $\lesssim \dfrac{2\Lambda}{\sqrt{N}}$ حيث $\Lambda = \|w\| \cdot \max_x \|x\|_*$ (الناظم مقروناً بثنويه). لدينا: $\|w\|_1 = 200$، $\|w\|_2 = 8$؛ وميزات صور 28×28 مُخزَّنة بمدى بكسل $[0,1]$ في الحالة (أ)، ومُطبَّعة بوحدة الناظم في الحالة (ب). عدد العيّنات $N = 10^4$.

المطلوب: أيّ اختيار للناظم يعطي حدّاً أحكم في كل حالة؟

الحل:

١. الحالة (أ) — الميزات الخام: $\max \|x\|_\infty = 1$ و $\max \|x\|_2 = \sqrt{784} = 28$.

- اقتران ℓ_1/ℓ_∞: $\Lambda_1 = \|w\|_1 \max \|x\|_\infty = 200 \times 1 = 200$.
- اقتران ℓ_2/ℓ_2: $\Lambda_2 = \|w\|_2 \max \|x\|_2 = 8 \times 28 = 224$.
- إذن $200 < 224$: **الاقتران** ℓ_1 **أحكم هنا**، رغم أن $\|w\|_1 = 200 \gg \|w\|_2 = 8$.
- الحدّان: $2 \times 200/100 = 4.00$ مقابل $2 \times 224/100 = 4.48$.

١. الحالة (ب) — بعد تطبيع الميزات إلى $\max \|x\|_2 = 1$ و $\max \|x\|_\infty \le 1$ (نأخذ 1 كأسوأ حالة).

- $\Lambda_1 = 200 \times 1 = 200$؛ $\Lambda_2 = 8 \times 1 = 8$.

- إذن $200 \gg 8$: **الاقتران** ℓ_2 **أحكم بـ** 25 **مرة.**

١. الاستنتاج: تطبيع الميزات غيّر أيّ ناظم أفضل — والفرق معامل 25.

النتيجة: الأفضلية ليست للناظم بل **للجداء** $\|x\|_* \cdot \max \|w\|$؛ وتطبيع الميزات يغيّر النتيجة جذرياً.
الربط بالذكاء الاصطناعي: هذه هي الرسالة المنهجية الأهم في هذا الفصل: حين تقرأ «حدّ تعميم يتناسب مع $\|w\|$»، اسأل فوراً: **ناظم** w **مقابل ناظم ثنوي لأيّ مجموعة ميزات؟** التحسين الحقيقي يأتي عادةً من جعل $\|x\|_*$ صغيراً (تطبيع، تبييض، تقليم الميزات) لا من تصغير $\|w\|$ وحده. وكل حدود التعميم في الجزء السادس مبنية على هذا الجداء بالضبط.

4.3.5 أخطاء شائعة في استخدام تكافؤ النواظم

الخطأ الشائع	لماذا هو خطأ؟	التصحيح
افتراض $\|x\|_2 \approx \|x\|_1$ في الأبعاد العالية	الفجوة تصل إلى $\sqrt{n}$: عند $n = 10^6$ معامل 1000	استخدم (13.5) صريحاً، ولا تترجم بين النواظم إلا بذكر المعامل
استخدام التكافؤ في فضاءات **الدوال** (أبعاد لانهائية)	التكافؤ يفشل: $\|f\|_\infty$ و $\|f\|_2$ غير متكافئين	تحقّق من منتهي البعد قبل تطبيق (14.5)
ظنّ أن الثوابت في (14.5) مستقلّة عن البعد	هي تعتمد على n صراحةً في عائلة ℓ_p	احتفظ بـ n (أو s إن وُجد تناثر) داخل الحدّ
تطبيق الحدّ الكثيف $\sqrt{d}$ على متجه متناثر	حدّ فضفاض بمعامل $\sqrt{d/s}$	استخدم (17.5): الثابت $\sqrt{s}$
اد أن «التقارب لا يعتمد على الناظم» يعني «نفس عدد الخطوات»	المعدّل نفسه، لكن الثابت يضيف خطوة $\frac{\ln \sqrt{n}}{\ln(1/\rho)}$	قِس الخطأ بناظم واحد عند مقارنة خوارزميتين
ترجمة عتبة استرجاع من ℓ_1 إلى ℓ_2 بعامل ثابت	العتبة تقابل مجالاً كاملاً باتساع $\sqrt{d}$	أعد ضبط العتبة على البيانات، ولا تترجمها
استخدام $\|W\|_F$ بديلاً عن $\|W\|_2$ بلا معامل	الفجوة حتى $\sqrt{\min(m,n)}$	اذكر الناظم المقصود؛ واستخدم التطبيع الطيفي إن كان المطلوب $\|W\|_2$
نقل λ (وزن التنظيم) بين نماذج مختلفة العرض	الجزاء الفعلي يتغيّر بعامل البعد	اضبط λ مع البعد، أو عبّر عن التنظيم بناظم مستهدف
تفسير تناثر Lasso بأنه «لأن ℓ_1 أصغر من ℓ_2»	السبب **هندسي**: أركان كرة ℓ_1 على المحاور	انظر إلى شكل كرة الوحدة، لا إلى قيمة الناظم
الاعتماد على الحدّ الأسوأ لتحليل أخطاء عشوائية (تكميم، تقريب)	الحدّ متشائم بمعامل يقارب $\sqrt{mn}/(\sqrt{m}+\sqrt{n})$	استخدم حدود التركيز الاحتمالية (6.5§)

الفكرة في سطر: المصفوفةُ **مشغّل** :(operator) تأخذ متجهاً وتُخرج متجهاً. فناظمها «الصحيح» ليس طولَها بوصفها قائمة أرقام، بل **أقصى تمديد** تُحدثه: $\max_{\|x\|=1} \|Ax\|$. هذه القراءة وحدها تُعطي الخاصية التي تجعل كل تحليل استقرار ممكناً — **التضاعف التحتي** $\|AB\| \leq \|A\|\,\|B\|$ — أي أن تمديدَ التركيب لا يتجاوز جداء التمديدات.

1.4.5 الصياغة الرسمية

تعريف (الناظم المستحث / ناظم المشغّل).

ليكن $A \in \mathbb{R}^{m\times n}$، وليكن $\|\cdot\|_\alpha$ ناظماً على $\mathbb{R}^n$ و $\|\cdot\|_\beta$ ناظماً على $\mathbb{R}^m$. الناظم المستحث من α إلى β هو:

$$\|A\|_{\alpha\to\beta} = \max_{\|x\|_\alpha=1} \|Ax\|_\beta = \max_{x\neq 0} \frac{\|Ax\|_\beta}{\|x\|_\alpha} = \sup_{x\neq 0} \frac{\|Ax\|_\beta}{\|x\|_\alpha} \tag{19.5}$$

جدول رموز (19.5):

الرمز	المعنى	ملاحظات
A	مصفوفة $m \times n$ = تحويل خطي $\mathbb{R}^n \to \mathbb{R}^m$	المشغّل
α	ناظم فضاء **المدخل** $\mathbb{R}^n$	—
β	ناظم فضاء **الخرج** $\mathbb{R}^m$	قد يختلف عن α
$\|A\|_{\alpha\to\beta}$	الناظم المستحث من α إلى β	يُقرأ: «ناظم المشغّل من α إلى β»
$\max_{\|x\|_\alpha=1}$	التعظيم على سطح كرة الوحدة للمدخل	يكافئ التعظيم على كل $x \neq 0$ بفضل التجانس
$\|Ax\|_\beta$	ناظم الخرج	البسط
$\|x\|_\alpha$	ناظم المدخل	المقام
$x \neq 0$	استبعاد المتجه الصفري	القسمة على صفر غير معرّفة
sup	الحدّ الأعلى	هنا يتحقّق كـ max لتراصّ كرة الوحدة

نظرية (النواظم الأربعة الكبرى وصيغها المغلقة).

لكل $A \in \mathbb{R}^{m\times n}$:

$$\begin{aligned} \|A\|_2 &= \|A\|_{2\to 2} = \sigma_1(A) = \sqrt{\lambda_{\max}(A^\top A)} = \sqrt{\lambda_{\max}(AA^\top)} \\ \|A\|_1 &= \|A\|_{1\to 1} = \max_{1\le j\le n} \sum_{i=1}^{m} |a_{ij}| \quad \text{(أكبر مجموع عمود)} \\ \|A\|_\infty &= \|A\|_{\infty\to\infty} = \max_{1\le i\le m} \sum_{j=1}^{n} |a_{ij}| \quad \text{(أكبر مجموع صف)} \\ \|A\|_F &= \|A\|_{S_2} = \sqrt{\operatorname{tr}(A^\top A)} = \sqrt{\textstyle\sum_{i,j} a_{ij}^2} = \sqrt{\textstyle\sum_i \sigma_i^2} \end{aligned} \tag{20.5}$$

جدول رموز (20.5):

الرمز	المعنى	ملاحظات
$\|A\|_2$	الناظم الطيفي = ناظم المشغّل الإقليدي	أكبر تمديد؛ = أكبر قيمة مفردة
$\sigma_1(A)$	أكبر قيمة مفردة (singular value) لـ A	$\sigma_1 \ge \sigma_2 \ge \cdots \ge 0$
$\lambda_{\max}(\cdot)$	أكبر قيمة ذاتية	للمصفوفات المتماثلة شبه الموجبة
$A^\top A$	مصفوفة غرام = $n \times n$ متماثلة شبه موجبة التحديد	قيمها الذاتية σ_i^2
$AA^\top$	نظيرتها $m \times m$	لها القيم الذاتية غير الصفرية نفسها
$\|A\|_1$	ناظم المشغّل لـ ℓ_1 للناظم	أكبر مجموع عمود بالمقياس المطلق
a_{ij}	العنصر في الصف i والعمود j	المدخلات الخام للمصفوفة
$\sum_i \|a_{ij}\|$	مجموع العمود j بالمقياس المطلق	نُعظّم على j
$\|A\|_\infty$	ناظم المشغّل لـ ℓ_∞ للناظم	أكبر مجموع صف بالمقياس المطلق
$\|A\|_F$	الناظم الفروبنيوسي	ليس ناظم مشغّل؛ هو ناظم شاتن S_2
$\operatorname{tr}(\cdot)$	الأثر (trace) = مجموع القطر	$\operatorname{tr}(A^\top A) = \sum_{ij} a_{ij}^2$
$\sum_i \sigma_i^2$	مجموع مربّعات القيم المفردة	$\|A\|_F^2$ = (متطابقة أساسية)

نظرية (التوافق والتضاعف التحتي).

لكل ناظم مستحث، وللمصفوفات المتوافقة الأبعاد:

$$\|Ax\|_\beta \le \|A\|_{\alpha\to\beta}\,\|x\|_\alpha, \qquad \|AB\| \;\le\; \|A\|\,\|B\| \tag{21.5}$$

وللناظم الفروبنيوسي تحديداً (وهو ليس ناظم مشغّل لكنه متوافق):

$$\|AB\|_F \le \|A\|_F \, \|B\|_F, \qquad \|AB\|_F \le \|A\|_2 \, \|B\|_F, \qquad \|AB\|_F \le \|A\|_F \, \|B\|_2 \tag{21b.5}$$

جدول رموز (21.5):

الرمز	المعنى	ملاحظات
$\|Ax\|_\beta \le \|A\|\|x\|_\alpha$	**التوافق** (consistency)	الناظم «يضبط» سلوك المشغّل
AB	جداء المصفوفتين = تركيب المشغّلين	يتطلّب توافق الأبعاد
$\|AB\| \le \|A\|\|B\|$	**التضاعف التحتي** (submultiplicativity)	أهم خاصية في هذا القسم
«لكل ناظم مستحث»	تشمل $\|\cdot\|_1$, $\|\cdot\|_2$, $\|\cdot\|_\infty$	ولا تشمل $\|\cdot\|_{\max}$ (أقصى إحداثي)
$\|\cdot\|_{\max}$	ناظم أقصى إحداثي مطلق	**ليس** متضاعفاً تحتياً — تحذير مهم
الأولى (21b.5)	تضاعف تحتي للفرونيوسي	$\|AB\|_F \le \|A\|_F \|B\|_F$
الثانية والثالثة (21b.5)	صيغ «مختلطة» أحكم	$\|AB\|_F \le \min\{\|A\|_2\|B\|_F,\ \|A\|_F\|B\|_2\}$
$\|\cdot\|_2$ في (21b.5)	الناظم الطيفي	هو الأصغر غالباً $\Longrightarrow$ الصيغة المختلطة أحكم

نظرية (نصف القطر الطيفي وصيغة غيلفاند).

ليكن $A \in \mathbb{R}^{n\times n}$ بقيم ذاتية $\lambda_1, \dots, \lambda_n$ **ونصف قطر طيفي** $\rho(A) = \max_i |\lambda_i|$. عندئذٍ:

$$\rho(A) \;=\; \lim_{k\to\infty} \left\|A^k\right\|^{1/k} \;=\; \inf_{k\ge 1} \left\|A^k\right\|^{1/k} \qquad \rho(A) \;\le\; \|A\| \quad \text{لكل ناظم مستحث}, \tag{22.5}$$

جدول رموز (22.5):

الرمز	المعنى	ملاحظات
$\rho(A)$	نصف القطر الطيفي = أكبر قيمة ذاتية بالمقياس المطلق	$\max_i \lvert\lambda_i\rvert$
λ_i	القيم الذاتية لـ A	قد تكون مركّبة
$\|A\|$	**أي** ناظم مستحث	العلاقة $\rho \le \|A\|$ عالمية
$\le$	نصف القطر أصغر من الناظم دائماً	الفجوة قد تكون كبيرة للمصفوفات غير الطبيعية
A^k	القوة الـ k للمصفوفة	A مضروبة في نفسها k مرة
$\|A^k\|^{1/k}$	الجذر الـ k لناظم القوة	يقترب من $\rho(A)$ تنازلياً
$\lim_{k\to\infty}$	نهاية المتتالية	صيغة غيلفاند (Gefland)
$\inf_{k\ge1}$	الحدّ الأدنى على كل k	يعطي تقديراً **من فوق** لـ ρ بـ k محدود
«غير طبيعية»	$A^\top A \ne AA^\top$	هنا تكون الفجوة $\rho \ll \|A\|$ كبيرة

نظرية (متراجحات تقاطعية بين النواظم المصفوفية).

لكل $A \in \mathbb{R}^{m\times n}$ برتبة r:

$$\|A\|_2 \;\le\; \sqrt{\|A\|_1 \, \|A\|_\infty} \;\le\; \sqrt{mn}\, \|A\|_{\max}, \qquad \|A\|_2 \;\le\; \|A\|_F \;\le\; \sqrt{r}\, \|A\|_2 \tag{23.5}$$

جدول رموز (23.5):

الرمز	المعنى	ملاحظات
$\sqrt{\|A\|_1\|A\|_\infty}$	حدّ تقاطعي رخيص على الناظم الطيفي	يحسب بجمع الأعمدة والصفوف فقط
$\|A\|_{\max}$	ناظم أقصى عنصر مطلق $= \max_{ij}\lvert a_{ij}\rvert$	أرخص ناظم حسابياً
$\sqrt{mn}$	الجذر التربيعي لجداء البُعدين	يظهر في الحدّ بـ $\|A\|_{\max}$؛ محكَم لمصفوفة كل عناصرها متساوية
$r = \operatorname{rank}(A)$	رتبة المصفوفة	$r \le \min(m,n)$
$\sqrt{r}$	معامل التحويل من الطيفي إلى الفرونيوسي	محكَم: يتحقّق عندما تتساوى القيم المفردة غير الصفرية
الفائدة العملية	حساب $\|A\|_2$ يحتاج SVD؛ الحدّ التقاطعي يحتاج $\mathcal{O}(nnz)$	حاسم للمصفوفات الضخمة

نظرية (متسلسلة نيومان وحدّ المعكوس).

إن كان $\|A\| < 1$ لناظم مستحث، فإن $I - A$ قابلة للعكس و:

$$(I-A)^{-1} = \sum_{k=0}^{\infty} A^k, \qquad \left\|(I-A)^{-1}\right\| \le \frac{1}{1-\|A\|} \tag{24.5}$$

جدول رموز (24.5):

الرمز	المعنى	ملاحظات
I	مصفوفة الوحدة	—
$I - A$	المصفوفة المراد عكسها	تظهر في كل مكان: معادلات تكرارية، أنظمة ديناميكية
$(I-A)^{-1}$	معكوسها	—
$\sum_{k=0}^{\infty} A^k$	متسلسلة نيومان = نظير المتسلسلة الهندسية للمصفوفات	تتقارب ffi $\rho(A) < 1$
$A^0 = I$	الحدّ الأول	—
$\|A\| < 1$	شرط كافٍ (أقوى من $\rho(A) < 1$)	مضمون بالناظم، أسهل تحقّقاً
$1/(1-\|A\|)$	حدّ على ناظم المعكوس	ينفجر عندما $\|A\| \to 1$
$1 - \|A\|$	«الهامش»	الفجوة عن الانفراد

نظرية (رقم الحالة وحساسية الحل).

ليكن A قابلة للعكس. رقم الحالة (بالناظم $\|\cdot\|$) والحساسية النسبية:

$$\kappa(A) = \|A\|\,\|A^{-1}\| \ge 1, \qquad \frac{\|\Delta x\|}{\|x\|} \le \kappa(A)\,\frac{\|\Delta b\|}{\|b\|}, \qquad \kappa_2(A) = \frac{\sigma_1}{\sigma_{\min}} \tag{25.5}$$

جدول رموز (25.5):

الرمز	المعنى	ملاحظات
$\kappa(A)$	رقم الحالة (condition number)	دائماً ≥ 1
$\|A^{-1}\|$	ناظم المعكوس	= «أدنى تمديد» مقلوباً: $1/\sigma_{\min}$ للناظم الطيفي
$\kappa \ge 1$	يتبع من $1 = \|I\| = \|AA^{-1}\| \le \|A\|\|A^{-1}\|$	—
Δx	الخطأ في الحل	$Ax = b$ يحلّ x
Δb	الاضطراب في الطرف الأيمن	—
$\frac{\|\Delta x\|}{\|x\|}$	الخطأ النسبي في الحل	المقدار المهم عملياً
$\frac{\|\Delta b\|}{\|b\|}$	الاضطراب النسبي في البيانات	—
$\kappa_2(A) = \sigma_1/\sigma_{\min}$	رقم الحالة الطيفي	المقياس القياسي لسوء التكييف
$\sigma_{\min}$	أصغر قيمة مفردة	اقترابها من الصفر $\Rightarrow$ انفجار رقم الحالة

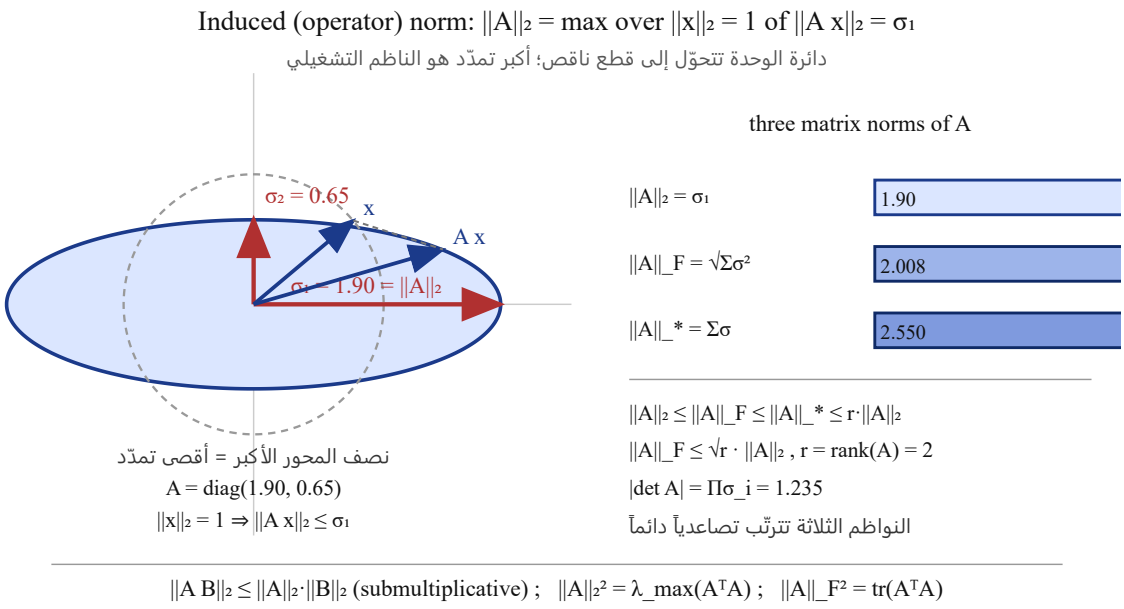
الشكل الهندسي: دائرة الوحدة تتحوّل إلى قطع ناقص، ونصف محوره الأكبر هو $\|A\|_2$:

2.4.5 البرهان

برهان $\|A\|_2 = \sigma_1$ في (20.5).

لناظم المشغّل الإقليدي:

$$\|A\|_2^2 = \max_{\|x\|_2=1} \|Ax\|_2^2 = \max_{x\neq 0} \frac{x^\top A^\top A\, x}{x^\top x}$$



شكل ٤.٥: *
الناظم المستحث هندسياً: دائرة الوحدة إلى قطع ناقص

وهذا بالضبط خارجُ قسمة رايلي للمصفوفة المتماثلة $A^\top A$؛ وبتوصيف رايلي–ريتز (انظر الفصل الرابع، (24.4)–(26.4)) قيمته القصوى هي $\lambda_{\max}(A^\top A)$. وحسب تعريف القيم المفردة $\sigma_i = \sqrt{\lambda_i(A^\top A)}$، نجد $\|A\|_2 = \sigma_1$. ■

برهان $\|A\|_1 = \max_j \sum_i |a_{ij}|$.

من متراجحة المثلث:

$$\|Ax\|_1 = \sum_i \Big|\sum_j a_{ij}x_j\Big| \le \sum_i \sum_j |a_{ij}||x_j| = \sum_j |x_j| \underbrace{\sum_i |a_{ij}|}_{\le C} \le C \sum_j |x_j| = C\|x\|_1$$

حيث $C = \max_j \sum_i |a_{ij}|$، فـ $\|A\|_1 \le C$. ولإثبات العكس نختار $x = e_{j^\star}$ عند العمود الأكبر: $\|Ae_{j^\star}\|_1 = \sum_i |a_{ij^\star}| = C$ و $\|e_{j^\star}\|_1 = 1 \Rightarrow \|A\|_1 \ge C$. ■

برهان $\|A\|_\infty$ بالتناظر

(نعكس دور الصفوف والأعمدة، أو نُطبّق النتيجة السابقة على $A^\top$ مع ملاحظة $\|A\|_\infty = \|A^\top\|_1$). ■

برهان التضاعف التحتي (21.5).

من التوافق مرّتين: $\|Bx\| \le \|B\|\,\|x\|$ و $\|ABx\| \le \|A\|\,\|Bx\|$. وبالتعظيم على $\|x\| = 1$: $\|AB\| \le \|A\|\,\|B\|$. ■

برهان $\rho(A) \le \|A\|$ في (22.5).

ليكن λ قيمة ذاتية أكبر بالمقياس المطلق و v متجهها الذاتي ($Av = \lambda v$، $v \neq 0$). من التوافق:

$$\rho(A)\,\|v\| \;=\; |\lambda|\,\|v\| \;=\; \|\lambda v\| \;=\; \|Av\| \;\le\; \|A\|\,\|v\|$$

وبالقسمة على $\|v\| > 0$: $\rho(A) \le \|A\|$. ■

برهان متسلسلة نيومان (24.5).

المجموع الجزئي $S_K = \sum_{k=0}^{K} A^k$ يحقّق $(I - A)S_K = I - A^{K+1}$. وبالتضاعف التحتي $\|A^{K+1}\| \le \|A\|^{K+1} \to 0$ لأن $\|A\| < 1$؛ فـ $S_K \to (I - A)^{-1}$، و:

$$\left\|(I - A)^{-1}\right\| \;\le\; \sum_{k=0}^{\infty} \|A\|^k \;=\; \frac{1}{1 - \|A\|} \qquad \blacksquare$$

برهان $\|A\|_2 \le \sqrt{\|A\|_1 \|A\|_\infty}$ في (23.5).

من (22.5) مطبّقاً على المصفوفة المتماثلة $A^\top A$:

$$\|A\|_2^2 \;=\; \rho(A^\top A) \;\le\; \|A^\top A\|_\infty \;\le\; \|A^\top\|_\infty\,\|A\|_\infty \;=\; \|A\|_1\,\|A\|_\infty$$

حيث استخدمنا $\|A^\top\|_\infty = \|A\|_1$. ■

برهان (25.5).

من $Ax = b$ و $A(x + \Delta x) = b + \Delta b$ نجد $A\Delta x = \Delta b$ فـ $\Delta x = A^{-1}\Delta b$؛ إذن $\|\Delta x\| \le \|A^{-1}\|\,\|\Delta b\|$. ومن $b = Ax$: $\|b\| \le \|A\|\,\|x\|$ فـ $\frac{1}{\|x\|} \le \frac{\|A\|}{\|b\|}$. بضرب المتراجحتين:

$$\frac{\|\Delta x\|}{\|x\|} \;\le\; \|A^{-1}\|\,\|\Delta b\| \cdot \frac{\|A\|}{\|b\|} \;=\; \kappa(A)\,\frac{\|\Delta b\|}{\|b\|} \qquad \blacksquare$$

تنبيه: الناظم الفروبينيوسي **ليس** ناظم مشغّل: $\|A\|_F \neq \max_{\|x\|_2=1} \|Ax\|_2$ (مثال: $A = I_n$ يعطي $\|I\|_F = \sqrt{n}$ في حين أن $\|I\|_2 = 1$). ومع ذلك فهو **متوافق**: $\|Ax\|_2 \le \|A\|_F \|x\|_2$، ويحقّق التضاعف التحتي (21b.5). وكذلك ناظم أقصى عنصر $\|A\|_{\max}$ **ليس** متضاعفاً تحتياً: مثال $A = B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ يعطي $\|A\|_{\max}\|B\|_{\max} = 1$ في حين أن $\|AB\|_{\max} = 2 > 1$.

3.4.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-4.5): الناظم الطيفي لطبقة خطية بوصفه ثابت ليبشيتز

المعطيات: مصفوفة أوزان $A = \begin{pmatrix} 1.2 & -0.4 \\ 0.6 & 1.1 \end{pmatrix}$.

المطلوب: احسب $\|A\|_2$ و $\|A\|_F$ وتحقّق من $\|A\|_2 \le \|A\|_F \le \sqrt{r}\|A\|_2$.

الحل:

١. $A^\top A = \begin{pmatrix} 1.44+0.36 & -0.48+0.66 \\ -0.48+0.66 & 0.16+1.21 \end{pmatrix} = \begin{pmatrix} 1.80 & 0.18 \\ 0.18 & 1.37 \end{pmatrix}$.

٢. الأثر $= 3.17$ والمحدِّد $= 1.80 \times 1.37 - 0.18^2 = 2.466 - 0.0324 = 2.4336$.

٣. القيمتان الذاتيتان: $\lambda = \dfrac{3.17 \pm \sqrt{10.0489 - 9.7344}}{2} = \dfrac{3.17 \pm 0.5608}{2}$، أي $\lambda_1 = 1.8654$ و $\lambda_2 = 1.3046$.

٤. القيمتان المفردتان: $\sigma_1 = \sqrt{1.8654} = 1.3658$ و $\sigma_2 = \sqrt{1.3046} = 1.1422$. إذن $\|A\|_2 = 1.3658$.

٥. $\|A\|_F = \sqrt{1.44 + 0.16 + 0.36 + 1.21} = \sqrt{3.17} = 1.7804$.

٦. التحقّق: $1.3658 \le 1.7804 \le \sqrt{2} \times 1.3658 = 1.9315$ ✓.

النتيجة: $\|A\|_2 = 1.3658$ و $\|A\|_F = 1.7804$.

الربط بالذكاء الاصطناعي: $\|A\|_2$ هو بالضبط **ثابت ليبشيتز** للطبقة الخطية: $\|Ax_1 - Ax_2\|_2 \le 1.3658\|x_1 - x_2\|_2$. ومع تفعيل ReLU (ذي ثابت ليبشيتز 1) يبقى ثابت الطبقة المركّبة 1.3658. سلسلة طبقات كهذه يُضرب ثوابتها — وهذا هو المبدأ الذي تقوم عليه الشبكات مقيَّدة ليبشيتز (Lipschitz networks) والتحقّق الرسمي من المتانة.

مثال (5.4-2): نواظم الصفوف والأعمدة والحدّ التقاطعي الرخيص على الناظم الطيفي

المعطيات: $A = \begin{pmatrix} 0.5 & -0.3 & 0.7 \\ -0.2 & 0.9 & 0.1 \\ 0.4 & 0.2 & -0.6 \end{pmatrix}$.

المطلوب: احسب $\|A\|_1$ و $\|A\|_\infty$ و $\|A\|_F$، واستخرج حدّاً على $\|A\|_2$ without SVD، ثم حدّاً أدنى له.

الحل:

١. مجاميع الأعمدة (مطلقة): $c_1 = 0.5 + 0.2 + 0.4 = 1.1$؛ $c_2 = 0.3 + 0.9 + 0.2 = 1.4$؛ $c_3 = 0.7 + 0.1 + 0.6 = 1.4$. $\Rightarrow \|A\|_1 = 1.4$.

٢. مجاميع الصفوف (مطلقة): $r_1 = 0.5 + 0.3 + 0.7 = 1.5$؛ $r_2 = 0.2 + 0.9 + 0.1 = 1.2$؛ $r_3 = 0.4 + 0.2 + 0.6 = 1.2$. $\Rightarrow \|A\|_\infty = 1.5$.

٣. $\|A\|_F = \sqrt{0.25 + 0.09 + 0.49 + 0.04 + 0.81 + 0.01 + 0.16 + 0.04 + 0.36} = \sqrt{2.25} = 1.5$.

٤. الحدّ التقاطعي (5.3-2): $\|A\|_2 \le \sqrt{1.4 \times 1.5} = \sqrt{2.10} = 1.4491$ — وهو **أحكم** من $\|A\|_F = 1.5$.

٥. حدّ أدنى: $\|A\|_2 = \|A^\top\|_2 \ge \max_i \|(A^\top)e_i\|_2 = \max_i$ (ناظم الصف i) $= \max(0.9110,\ 0.9274,\ 0.7483) = 0.9274$. $= \max(\sqrt{0.83}, \sqrt{0.86}, \sqrt{0.56})$.

٦. إذن $\|A\|_2 \in [0.9274,\ 1.4491]$.

النتيجة: $\|A\|_1 = 1.4$، $\|A\|_\infty = 1.5$، $\|A\|_F = 1.5$، و $\|A\|_2 \in [0.9274,\ 1.4491]$.
الربط بالذكاء الاصطناعي: حساب SVD لمصفوفة 4096×4096 مكلِف، أمّا $\|A\|_1$ و $\|A\|_\infty$ فمجرد مجاميع على الأعمدة والصفوف — تكلفة $\mathcal{O}(nnz)$ وتعمل على مصفوفات متناثرة ضخمة. حدّ (23.5) هو الأداة اليومية لتقدير سريع للناظم الطيفي في التطبيع الطيفي التقريبي (approximate spectral normalization) وفي مراقبة استقرار التدريب.

مثال (4.5-3): التضاعف التحتي على سلسلة طبقتين — كم هو فضفاض الحدّ؟

المعطيات: $W_1 = \begin{pmatrix} 1.5 & 0 \\ 0 & 2.1 \end{pmatrix}$ و $W_2 = \begin{pmatrix} 1.7 & 0 \\ 0 & 0.3 \end{pmatrix}$.
المطلوب: قارن $\|W_2 W_1\|_2$ الفعلي بجداء النواظم الطيفية وبجداء النواظم الفرونيوسية.
الحل:

١. $\|W_1\|_2 = 2.1$ و $\|W_2\|_2 = 1.7$ (مصفوفتان قطريتان: القيم المفردة على القطر).

٢. جداء النواظم الطيفية (الحدّ): $\|W_2 W_1\|_2 \le 1.7 \times 2.1 = 3.57$.

٣. القيمة الفعلية: $W_2 W_1 = \begin{pmatrix} 2.55 & 0 \\ 0 & 0.63 \end{pmatrix} \Rightarrow \|W_2 W_1\|_2 = 2.55$.

٤. النواظم الفرونيوسية: $\|W_1\|_F = \sqrt{2.25 + 4.41} = \sqrt{6.66} = 2.5807$، $\|W_2\|_F = \sqrt{2.89 + 0.09} = \sqrt{2.98} = 1.7263$؛ الحدّ $= 4.4551$.

٥. $\|W_2 W_1\|_F = \sqrt{6.5025 + 0.3969} = \sqrt{6.8994} = 2.6266$.

٦. الترتيب: 2.55 (فعلي) ≤ 3.57 (طيفي) ≤ 4.4551 (فرونيوسي).

النتيجة: حدّ النواظم الطيفية فضفاض بمعامل $3.57/2.55 = 1.40$؛ وحدّ الفرونيوسية بمعامل $4.4551/2.55 = 1.75$.
الربط بالذكاء الاصطناعي: الحدّ فضفاض هنا لأن الاتجاه الذي يمدّده W_1 أكثر ما يمكن (المحور الثاني) ليس الاتجاه الذي يمدّده W_2 أكثر ما يمكن (المحور الأول) — أي أن القيم المفردة «غير متوازية». في الشبكات العميقة، جداء النواظم الطيفية عبر الطبقات قد يكون فضفاضاً بمراتب، وهذا بالضبط ما يجعل «التحقّق الرسمي» متحفّظاً مقارنة بالمتانة الفعلية. لكنه الحدّ الوحيد المضمون **بلا فحص للتركيب**، ولهذا يُستخدم في الشهادات.

مثال (4.5-4): نصف القطر الطيفي مقابل الناظم الطيفي — النمو العابر في الشبكات التكرارية

المعطيات: مصفوفة انتقال حالة تكرارية $A = \begin{pmatrix} 0.9 & 1.0 \\ 0 & 0.9 \end{pmatrix}$.
المطلوب: احسب $\rho(A)$ و $\|A\|_2$، ثم بيّن أن $\|A^k\|$ قد ينمو أولاً ثم يزول رغم أن $\rho(A) < 1$.
الحل:

١. القيم الذاتية (مثلثية): $\rho(A) = 0.9 < 1 \implies \lambda_1 = \lambda_2 = 0.9$. $A^k \to 0$.

٢. $A^\top A = \begin{pmatrix} 0.81 & 0.9 \\ 0.9 & 1.81 \end{pmatrix}$؛ الأثر $= 2.62$، المحدِّد $= 0.81 \times 1.81 - 0.81 = 0.6561$.

٣. $\|A\|_2 = \sqrt{\lambda_1}$، $\lambda_1 = 2.3396 \implies \lambda = \dfrac{2.62 \pm \sqrt{6.8644 - 2.6244}}{2} = \dfrac{2.62 \pm 2.0591}{2}$
$\sqrt{2.3396} = 1.5296$.

٤. الفجوة: $\|A\|_2 = 1.5296 > \rho(A) = 0.9$ بمعامل 1.70 — لأن A **غير طبيعية**.

٥. القوى: $A^k = \begin{pmatrix} 0.9^k & k\,0.9^{k-1} \\ 0 & 0.9^k \end{pmatrix}$. عند $k = 5$: $A^5 = \begin{pmatrix} 0.5905 & 3.2805 \\ 0 & 0.5905 \end{pmatrix}$ وناظمه الفروبنيوسي $= \sqrt{0.3487 + 10.7617 + 0.3487} = \sqrt{11.4591} = 3.385$ — **أكبر من $\|A\|_2$ نفسه!**

٦. ثم يزول: عند $k = 20$: $0.9^{20} = 0.1216$، و $20 \times 0.9^{19} = 2.7018$، فـ $\|A^{20}\|_F \approx 2.707$ — في طريقه إلى الصفر.

النتيجة: $\rho(A) = 0.9$ (مستقر نهائياً)، لكن $\|A^5\| \approx 3.38$ — **نمو عابر** بمعامل يقارب 3.8 قبل الزوال.

الربط بالذكاء الاصطناعي: هذه هي الرياضيات الدقيقة لظاهرتَي **انفجار وتلاشي التدرّج** في RNN. الشرط الصحيح للاستقرار النهائي هو $\rho(A) < 1$ لا $\|A\| < 1$؛ لكن النمو العابر (transient growth) الناشئ عن عدم الطبيعية (non-normality) هو ما يجعل التدريب فعلياً غير مستقر رغم الاستقرار النظري. ولهذا تُستخدم **الوحدوية** (orthogonal/unitary RNN) التي تجعل $\|A\|_2 = 1$ وتمنع النمو العابر تماماً.

مثال (5-4.5): تقدير نصف القطر الطيفي بصيغة غيلفاند

المعطيات: $A = \begin{pmatrix} 0.8 & 1.0 \\ 0 & 0.4 \end{pmatrix}$.

المطلوب: احسب $\rho(A)$ بالتحليل، ثم قدّره بـ $\|A^k\|^{1/k}$ عند $k = 1, 2, 4, 8$ وتحقّق من التناقص نحو ρ.

الحل:

١. القيم الذاتية (مثلثية): 0.8 و $0.4 \implies \rho(A) = 0.8$.

٢. شكل القوى: $A^k = \begin{pmatrix} 0.8^k & c_k \\ 0 & 0.4^k \end{pmatrix}$ حيث $c_k = \dfrac{0.8^k - 0.4^k}{0.8 - 0.4}$.

٣. $k = 1$: $c_1 = 1.0$؛ $\|A\|_F = \sqrt{0.64 + 1 + 0.16} = \sqrt{1.80} = 1.3416 \implies \|A\|_F^{1/1} = 1.3416$.

٤. $k = 2$: $c_2 = \dfrac{0.64 - 0.16}{0.4} = 1.2$؛ $\|A^2\|_F = \sqrt{0.4096 + 1.44 + 0.0256} = \sqrt{1.8752} = 1.3694 \implies 1.1702^{1/2}$.

٥. $k = 4$: $c_4 = \dfrac{0.4096 - 0.0256}{0.4} = 0.96$؛ $\|A^4\|_F = \sqrt{0.16777 + 0.9216 + 0.000655} = \sqrt{1.09003} = 1.0440 \implies 1.0108^{1/4}$.

٦. $k = 8$: $\|A^8\|_F = \sqrt{0.02814 + 0.17455 + 4.3 \times 10^{-7}} = \sqrt{0.20269} = 0.4502$، $c_8 = \dfrac{0.16777 - 0.000655}{0.4} = 0.41779$؛ $\Longrightarrow 0.9051 = 0.4502^{1/8}$.

٧. المتتالية: $0.8 \to 0.9051 \to \cdots \to 1.0108 \to 1.1702 \to 1.3416$، وهي **متناقصة** وتفوق $\rho = 0.8$ دائماً (inf يعطي حداً من فوق).

النتيجة: $\rho(A) = 0.8$، وأفضل تقدير بـ k محدود هو 0.9051 عند $k = 8$ (خطأ $+13\%$).

الربط بالذكاء الاصطناعي: صيغة غيلفاند هي الأداة العملية لفحص استقرار الأنظمة الديناميكية المُتعلَّمة (Neural ODE)، الشبكات التكرارية العميقة، (equilibrium models) حين لا نريد حساب القيم الذاتية: نحسب ناظم قوةٍ عالية A^{2^j} (بالتكرير المتكرّر) ونأخذ الجذر. ولأن المتتالية متناقصة، فكل تقدير هو **حدّ أعلى مضمون** — أي أن الفحص «متحفّظ دائماً» ولا يعلن الاستقرار زوراً.

مثال (5.4-6): متسلسلة نيومان في طبقة ضمنية (implicit layer)

المعطيات: طبقة ضمنية تُعرَّف بالعلاقة $x = Ax + b$ حيث $A = \begin{pmatrix} 0.4 & 0.3 \\ -0.3 & 0.4 \end{pmatrix}$، و b ثابت. الحل $x^\star = (I - A)^{-1}b$ يُحسب تكرارياً: $x_{k+1} = Ax_k + b$ ببداية $x_0 = b$، و $\|x_1 - x_0\| = 1$.

المطلوب: حدّ على $\|(I - A)^{-1}\|_2$، والقيمة الدقيقة، وعدد التكرارات اللازمة لدقة 10^{-4}.

الحل:

١. نلاحظ أن عمودَي A متعامدان متساويا الطول: $A^\top A = 0.25\, I \Longrightarrow \sigma_1 = \sigma_2 = 0.5 \Longrightarrow \|A\|_2 = 0.5 < 1$ ✓ (شرط نيومان متحقّق).

٢. حدّ نيومان: $\|(I - A)^{-1}\|_2 \le \dfrac{1}{1 - 0.5} = 2.0$.

٣. القيمة الدقيقة: $I - A = \begin{pmatrix} 0.6 & -0.3 \\ 0.3 & 0.6 \end{pmatrix}$، و $(I - A)^\top (I - A) = 0.45\, I \Longrightarrow$ قيمه المفردة كلها $\sqrt{0.45} = 0.67082$ $\Longrightarrow \|(I - A)^{-1}\|_2 = 1/0.67082 = 1.4907$.

٤. التحقّق: $1.4907 \le 2.0$ ✓ (الحدّ صحيح وفضفاض بمعامل 1.34).

٥. عدد التكرارات: $\|x_k - x^\star\| \le \dfrac{\|A\|^k}{1 - \|A\|}\|x_1 - x_0\| = 2 \times 0.5^k$. نحتاج $2 \times 0.5^k \le 10^{-4} \Longrightarrow 0.5^k \le 5 \times 10^{-5}$ $\Longrightarrow k \ge \log_2(2 \times 10^4) = 14.29 \Longrightarrow k = 15$.

النتيجة: $\|(I - A)^{-1}\|_2 = 1.4907 \le 2.0$، ونحتاج 15 تكراراً لدقة 10^{-4}.

الربط بالذكاء الاصطناعي: الطبقات الضمنية (implicit layers)، DEQ (equilibrium models) تحلّ بالضبط معادلةً من هذا النوع، وشرط تقاربها $\|A\| < 1$ هو نفسه شرط متسلسلة نيومان. حدّ $\frac{1}{1-\|A\|}$ يخبرنا أيضاً بسلوك التدرّج: $\frac{\partial x^\star}{\partial b} = (I - A)^{-1}$، فاقتراب $\|A\|$ من 1 يجعل التدرّج ينفجر — ولهذا تُقيَّد هذه النماذج بتطبيع طيفي صريح.

مثال (5.4-7): رقم الحالة وحساسية المربّعات الصغرى

المعطيات: $A = \begin{pmatrix} 1 & 1 \\ 1 & 1.01 \end{pmatrix}$، ونريد حلّ $Ax = b$.

المطلوب: احسب القيمتين المفردتين و $\kappa_2(A)$، ثم قدّر أسوأ خطأ نسبي في الحل عند اضطراب نسبي مقداره 10^{-3} في b.

الحل:

١. $\det A = 1 \times 1.01 - 1 \times 1 = 0.01$؛ و $\|A\|_F^2 = 1 + 1 + 1 + 1.0201 = 4.0201$.

٢. من $\sigma_1\sigma_2 = |\det A| = 0.01$ و $\sigma_1^2 + \sigma_2^2 = 4.0201$: نضع $\sigma_2 = 0.01/\sigma_1$ فنحصل $\sigma_1^2 + 10^{-4}/\sigma_1^2 = 4.0201 \Longrightarrow \sigma_1^2 \approx 4.020075 \Longrightarrow \sigma_1 = 2.00501$، و $\sigma_2 = 0.01/2.00501 = 0.0049875$.

٣. رقم الحالة: $\kappa_2(A) = \dfrac{2.00501}{0.0049875} = 402.0$.

٤. الحساسية (5.25): $\dfrac{\|\Delta x\|}{\|x\|} \le 402.0 \times 10^{-3} = 0.402$.

٥. المقارنة بمصفوفة حسنة التكييف: $\kappa_2 = 1 \Longrightarrow \sigma_1 = \sigma_2 = \sqrt{2} \Longrightarrow A'^{\top}A' = 2I \Longrightarrow A' = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$ $\Longrightarrow$ الخطأ النسبي $\le 10^{-3}$.

النتيجة: $\kappa_2(A) = 402$ — أي أن خطأً نسبياً مقداره 0.1% في البيانات قد يُنتج خطأً نسبياً حتى 40% في الحل.

الربط بالذكاء الاصطناعي: سوء التكييف هو سبب رئيسي لعدم استقرار تدريب الشبكات: مصفوفات الغرام $X^{\top}X$ ذات الميزات المترابطة تكون سيّئة التكييف، فتتضخّم التحديثات في اتجاهات القيم الذاتية الصغيرة. العلاجات الثلاثة الشائعة — التنظيم (يزيد $\sigma_{\min}$ فعلياً)، وتطبيع الدفعات/الطبقات (يُحسّن تكييف ميزات المدخل)، و Adam (يقيس التحديثات بمقياس متوازن) — هي جميعاً استجابات لرقم الحالة.

مثال (5.4-8): حدّ تقاطعي رخيص للناظم الطيفي في طبقة ضخمة 4096×512

المعطيات: طبقة $W \in \mathbb{R}^{4096\times 512}$، أكبر مجموع عمود $\|W\|_1 = 12.4$، وأكبر مجموع صف $\|W\|_\infty = 1.8$، وأكبر عنصر مطلق $\|W\|_{\max} = 0.05$.

المطلوب: قدّر $\|W\|_2$ بالحدّين في (5.23) وقارن.

الحل:

١. الحدّ التقاطعي (صفوف/أعمدة): $\|W\|_2 \le \sqrt{12.4 \times 1.8} = \sqrt{22.32} = 4.7246$.

٢. حدّ أقصى عنصر: $\|W\|_2 \le \sqrt{mn}\,\|W\|_{\max} = \sqrt{4096 \times 512} \times 0.05 = \sqrt{2097152} \times 0.05 = 1448.15 \times 0.05 = 72.41$.

٣. نأخذ الأحكم (الأصغر): $\|W\|_2 \le 4.7246$ — وهو أحكم من حدّ أقصى عنصر بـ $72.41/4.7246 = 15.3$ مرة.

٤. التكلفة: الحدّان معاً يحتاجان مجاميع على الصفوف والأعمدة وإيجاداً لأكبر عنصر — كلها $\mathcal{O}(mn)$ أو $\mathcal{O}(nnz)$، مقابل $\mathcal{O}\big(mn\min(m,n)\big)$ لـ SVD كاملة — أي توفير بمراتب.

٥. ملاحظة: لا يسود أحد الحدّين الآخر دائماً. حدّ أقصى عنصر يسود إذا كانت العناصر صغيرة ومتساوية المقدار؛ والحدّ التقاطعي يسود إذا تركّز الناظم في صفوف أو أعمدة قليلة سميكة (كما في هذه الحالة: مجموع عمود يبلغ 12.4 مع عنصر أعظمي 0.05 يعني عموداً كثيفاً).

النتيجة: $\|W\|_2 \le 4.7246$ بالحدّ التقاطعي، و ≤ 72.41 بحدّ أقصى عنصر، نأخذ الأحكم: 4.7246.

الربط بالذكاء الاصطناعي: القاعدة العملية: **احسب الحدّين وخذ الأحكم.** لا أحدهما يسود الآخر دائماً: حدّ أقصى عنصر يسود حين تكون العناصر متساوية المقدار تقريباً، والحدّ التقاطعي يسود حين يتركّز الناظم في صفوف/أعمدة قليلة سميكة. هذه الحدود الرخيصة تُستخدم في «التطبيع الطيفي بقوة واحدة» spectral (power-iteration norm) وفي مراقبة تضخّم الناظم أثناء التدريب بتكلفة لا تُذكر.

مثال (5.4-9): القصّ بالفرونيوسي مقابل الطيفي — كم يتغيّر ثابت ليبشيتز فعلاً؟

المعطيات: تدرّج $G \in \mathbb{R}^{256\times 128}$ بـ $\|G\|_F = 3.4$ و $\|G\|_2 = 0.9$؛ معدّل تعلّم η. التحديث $\Delta W = -\eta\, G$ مقصوص بشرط $\|\Delta W\|_F \le 1.0$.

المطلوب: حدّ على التغيّر في الناظم الطيفي للطبقة (أي في ثابت ليبشيتز) بعد التحديث، ومقارنته بالقيمة النموذجية.

الحل:

١. التحقّق من الترتيب: $\|G\|_2 = 0.9 \le \|G\|_F = 3.4 \le \sqrt{128}\times 0.9 = 10.18$ ✓ $(r \le 128)$.

٢. بعد القصّ إلى $\|\Delta W\|_F \le 1.0$: معامل القصّ $= 1.0/(\eta \times 3.4)$؛ فالتحديث المقصوص ناظمه الطيفي $= 0.9 \times \frac{1.0}{3.4} = 0.2647$.

٣. الحدّ المضمون على التغيّر الطيفي: $\|\Delta W\|_2 \le \|\Delta W\|_F \le 1.0$ — أي أن ثابت ليبشيتز قد يتغيّر حتى 1.0.

٤. القيمة الفعلية (بافتراض أن القصّ يُبقي الاتجاه): $\|\Delta W\|_2 = 0.2647$.

٥. الفجوة بين الحدّ والقيمة: $1.0/0.2647 = 3.78$ مرة.

النتيجة: القصّ الفرونيوسي يضمن $\|\Delta W\|_2 \le 1.0$ لكنه فعلياً يُحدث تغيّراً طيفياً مقداره ≈ 0.26.

الربط بالذكاء الاصطناعي: الطبقة تتصرّف بوصفها **مشغّلاً**، فالكمية المهمة هي $\|W\|_2$ لا $\|W\|_F$. القصّ الفرونيوسي (الشائع في clip_grad_norm_) يضبط الطول بوصفه قائمة أرقام، ويترك تغيّراً غير مضبوط بدقة في ثابت ليبشيتز بمعامل حتى $\sqrt{r} \approx 11$. حين يكون الاستقرار هدفاً صريحاً (تدريب خصمي، تدفّقات مقيَّدة، نماذج انتشارية)، يُستعمل القصّ أو التنظيم على الناظم الطيفي مباشرة.

مثال (10-4.5): ثابت ليبشيتز لشبكة من أربع طبقات — جداء طيفي مقابل جداء فرونيوسي

المعطيات: أربع طبقات بعرض 256: النواظم الطيفية $(1.8,\ 2.2,\ 1.5,\ 2.0)$؛ والنواظم الفرونيوسية $(18.4,\ 22.7,\ 15.2,\ 20.1)$. التفعيلات ReLU (ثابت ليبشيتز 1).

المطلوب: حدّان على ثابت ليبشيتز الشبكة كلها، ونسبة الفجوة بينهما.

الحل:

١. حدّ جداء النواظم الطيفية: $L_{\text{spec}} = 1.8 \times 2.2 \times 1.5 \times 2.0$.

- $1.8 \times 2.2 = 3.96$، $1.5 \times 2.0 = 3.0$، المجموع: $3.96 \times 3.0 = 11.88$.

١. حدّ جداء النواظم الفرونيوسية: $L_F = 18.4 \times 22.7 \times 15.2 \times 20.1$.

- $18.4 \times 22.7 = 417.68$، $15.2 \times 20.1 = 305.52$، المجموع: $417.68 \times 305.52 = 1.276 \times 10^5$.

١. نسبة الفجوة: $1.276 \times 10^5 / 11.88 = 1.074 \times 10^4$ — **أي أربعة مراتب!**

٢. التفسير: $\frac{20.1}{2.0} = 10.05$, $\frac{15.2}{1.5} = 10.1$, $\frac{22.7}{2.2} = 10.3$, $\frac{18.4}{1.8} = 10.2$ $\approx$ $\frac{\|W_i\|_F}{\|W_i\|_2}$ — كل طبقة تُدخل معاملاً ≈ 10، والمجموع 10^4.

النتيجة: $L \le 11.88$ بالحدّ الطيفي، مقابل $L \le 1.276 \times 10^5$ بالحدّ الفرونيوسي — فجوة بمراتب أربع.

الربط بالذكاء الاصطناعي: هذا المثال يوضّح لماذا يُعدّ **التطبيع الطيفي** (spectral normalization) — وهو الذي يضبط $\|W\|_2$ لكل طبقة — الأداةَ الفعّالة في WGAN والشبكات مقيَّدة ليبشيتز، بينما تنظيم $\|W\|_F$ (weight decay العادي) لا يعطي تحكّماً ذا معنى في ثابت ليبشيتز العميق. القاعدة: **للتحليل استخدم الناظم الطيفي؛ للحساب استخدم ما هو أرخص ثم حوّل.**

مثال (11-4.5): مصفوفة عشوائية الصفوف — عدم التوسّع في ℓ_∞ (تمرير الرسائل والانتباه)

المعطيات: مصفوفة انتقال $P = \begin{pmatrix} 0.6 & 0.4 & 0 \\ 0.2 & 0.5 & 0.3 \\ 0.1 & 0.1 & 0.8 \end{pmatrix}$ (صفوفها غير سالبة ومجموع كل صف $= 1$).

المطلوب: احسب $\|P\|_1$ و $\|P\|_\infty$ و $\rho(P)$، وحدّاً على $\|P\|_2$، واستنتج سلوك التطبيق المتكرّر.

الحل:

١. مجاميع الصفوف $= (1.0,\ 1.0,\ 1.0) \Longrightarrow \|P\|_\infty = 1.0$.

٢. مجاميع الأعمدة: $c_1 = 0.6+0.2+0.1 = 0.9$، $c_2 = 0.4+0.5+0.1 = 1.0$، $c_3 = 0+0.3+0.8 = 1.1$ $\Longrightarrow \|P\|_1 = 1.1$.

٣. $\rho(P) = 1$ (لكل مصفوفة عشوائية قيمة ذاتية 1 مع المتجه **1**)، والتحقّق: $\rho \le \|P\|_\infty = 1$ ✓.

٤. $\|P\|_2 \le \sqrt{1.1 \times 1.0} = 1.0488$.

٥. عدم التوسّع في ℓ_∞: $\|Px\|_\infty \le \|P\|_\infty \|x\|_\infty = \|x\|_\infty$ — كل إحداثي في الخرج هو **تركيبة محدّبة** من إحداثيات المدخل، فلا يتجاوز أكبرها.

النتيجة: تطبيق P مرّات متكرّرة لا يمكن أن يضخّم $\|\cdot\|_\infty$ — و $\rho(P) = 1$ يعني أن التوزيع يستقرّ ولا ينفجر.

الربط بالذكاء الاصطناعي: هذا هو الضمان الكامن خلف استقرار الشبكات العصبية البيانية (GNN) وطبقات الانتباه المُقنَّعة حين تكون مصفوفة الخلط عشوائية الصفوف: تمرير الرسائل يبقى **تركيبةً محدّبة** فلا تنفجر قيم العُقد مها تعمّقت الشبكة (خلافاً للابلاسيد الخام أو المصفوفات غير المُطبَّعة). وهو أيضاً سبب شيوع «التنعيم المفرط» (over-smoothing): عدم التوسّع يعني أن التطبيق المتكرّر يُقارب الإحداثيات نحو المتوسط — انهيار تدريجي لا انفجار.

مثال (5.4-12): ناظم المعكوس وأدنى تمديد — الحساسية من الجهة الأخرى

المعطيات: $A = \begin{pmatrix} 2 & 0 \\ 0 & 0.25 \end{pmatrix}$ و $b = (1, 1)^\top$ واضطراب $\Delta b = (0.01,\ 0)^\top$.

المطلوب: احسب $\|A\|_2$ و $\|A^{-1}\|_2$ و $\kappa_2(A)$، ثم قارن الخطأ النسبي الفعلي في الحل بحدّ (25.5).

الحل:

١. القيم المفردة (قطرية): $\sigma_1 = 2$، $\sigma_2 = 0.25$ $\Longrightarrow$ $\|A\|_2 = 2$.

٢. $A^{-1} = \begin{pmatrix} 0.5 & 0 \\ 0 & 4 \end{pmatrix}$ $\Longrightarrow$ قيمها المفردة $(0.5,\ 4)$ $\Longrightarrow$ $\|A^{-1}\|_2 = 4 = 1/\sigma_{\min}$ ✓.

٣. $\kappa_2(A) = 2 \times 4 = 8$.

٤. التمديد: لـ $\|x\|_2 = 1$ يقع $\|Ax\|_2$ في $[0.25,\ 2]$ — الإحداثي الثاني **يُضغط** إلى ربْع قيمته.

٥. الحل: $x = A^{-1}b = (0.5,\ 4)^\top$؛ $\|x\|_2 = \sqrt{0.25 + 16} = 4.0311$.

٦. $\Delta x = A^{-1}\Delta b = (0.005,\ 0)^\top$؛ $\|\Delta x\|_2 = 0.005$؛ الخطأ النسبي $= 0.005/4.0311 = 0.001240$.

٧. الاضطراب النسبي: $\|\Delta b\|_2/\|b\|_2 = 0.01/\sqrt{2} = 0.007071$.

٨. الحدّ: $0.001240 \ge 0.05657 = 8 \times 0.007071$ ✓ $\kappa_2 \times$ — صحيح وفضفاض بمعامل 45.6.

النتيجة: $\kappa_2 = 8$، والخطأ النسبي الفعلي 0.124% يقع تحت الحدّ المضمون 5.66%.

الربط بالذكاء الاصطناعي: $\|A^{-1}\|_2 = 1/\sigma_{\min}$ يعني أن أصغر قيمة مفردة تحدّد **أدنى تمديد**: كلّما صغُرت، صار بالإمكان «إخفاء» اضطرابات كبيرة في اتجاهها، وتضخّمت عند العكس. وفي الشبكات، اتجاهات القيم المفردة الصغيرة للجاكوبي هي اتجاهات «العمى»: المدخلات فيها لا تُحدث أثراً يُذكر في الخرج — وهي تحديداً الاتجاهات التي تستغلّها الهجمات الخصمية (حساسية عالية عند العكس، أثر ضئيل عند الأمام).

مثال (5.4-13): استقرار التوصيلات المتبقّية (residual connections) و«مقياس التوصيلة»

المعطيات: شبكة من $L = 50$ كُتَل متبقّية: $x_{l+1} = x_l + W_l x_l = (I + W_l)x_l$، بـ $\|W_l\|_2 = 0.15$ لكل l.
المطلوب: حدّ على ناظم المشغّل الكلي، وأثر إدخال مقياس تصغير α على فرع التوصيلة.
الحل:

١. لكل كتلة: $\|I + W_l\|_2 \le \|I\|_2 + \|W_l\|_2 = 1 + 0.15 = 1.15$؛ وبالمتراجحة الفرقية $\|I + W_l\|_2 \ge |1 - 0.15| = 0.85$.

٢. بالتضاعف التحتي على 50 كتلة: $\left\|\prod_l (I + W_l)\right\|_2 \le 1.15^{50}$.

٣. الحساب: $\ln(1.15) = 0.13976$، $\times 50 = 6.988$؛ $e^{6.988} = 1082$.

٤. بمقياس تصغير $\alpha = 0.1$: $\|I + \alpha W_l\|_2 \le 1 + 0.015 = 1.015$؛ و $1.015^{50} = e^{50 \times 0.014889} = e^{0.7444} = 2.105$.

٥. التحسين: $1082 / 2.105 = 514$ مرة.

النتيجة: الحدّ الأسوأ يتحسّن من 1082 إلى ≈ 2.1 بمجرّد تصغير فرع التوصيلة بمعامل 10.
الربط بالذكاء الاصطناعي: هذا هو المبرّر الرياضي المباشر لتقنيات مثل **residual / SkipInit / ReZero scaling** التي تُضاعف فرع التوصيلة بمعامل صغير قابل للتعلّم (أو تُهيّئه بالصفر): فهي تحوّل النموّ الأُسّي $(1 + \|W\|)^L$ إلى $(1 + \alpha\|W\|)^L$ القريب من 1. وبدونها، حتى ناظم طيفي صغير لكل كتلة (0.15) يُنتج انفجاراً بمعامل 10^3 بعد 50 كتلة — وهو بالضبط سبب الحاجة إلى LayerNorm/Pre-LN في المحوّلات العميقة.

مثال (5.4-14): مصفوفة الالتفاف — لماذا الناظم الطيفي مستقل عن حجم الصورة والفرونيوسي ليس كذلك؟

المعطيات: نواة التفاف 3×3: $k = \begin{pmatrix} 0.2 & -0.1 & 0.05 \\ -0.3 & 0.4 & -0.1 \\ 0.1 & -0.05 & 0.15 \end{pmatrix}$، تُطبَّق بـ «same» padding على صورة من N بكسل. المصفوفة المرافقة $C \in \mathbb{R}^{N \times N}$.
المطلوب: حدّ على $\|C\|_2$، ومقارنته بـ $\|C\|_F$، والاستنتاج.
الحل:

١. كل صف من C يحوي على الأكثر عناصر النواة التسعة $\Longrightarrow$ مجموع الصفوف المطلق $\le \sum_{ij} |k_{ij}|$.

٢. $\|C\|_\infty \le 1.45$ إذن $\sum |k| = 0.2 + 0.1 + 0.05 + 0.3 + 0.4 + 0.1 + 0.1 + 0.05 + 0.15 = 1.45$؛ وبالمثل $\|C\|_1 \le 1.45$ (كل عمود يحوي على الأكثر تسعة عناصر).

٣. من (23.5): $\|C\|_2 \le \sqrt{1.45 \times 1.45} = 1.45$ — **مستقل عن N**.

٤. $\|C\|_F$: كل صف داخلي ناظمه $\sqrt{\sum k^2} = \sqrt{0.3475} = 0.5895$، إذن $\|C\|_F \approx 0.5895\sqrt{N}$ — **ينمو مع $\sqrt{N}$**.

٥. مثال عددي: لصورة 512×512 ($N = 262144$): $\|C\|_F \approx 0.5895 \times 512 = 301.8$، في حين أن $\|C\|_2 \leq 1.45$.

النتيجة: $\|C\|_2 \leq 1.45$ لأي حجم صورة، بينما $\|C\|_F \approx 0.59\sqrt{N}$ يتضخّم معها.

الربط بالذكاء الاصطناعي: الالتفاف **مشغّل** مترجمٌ-الثبات (translation-equivariant)؛ ناظمه الطيفي يساوي أقصى استجابة تردّدية للنواة (قيمة ثابتة لا تتأثّر بحجم الصورة) — في حين أن الناظم الفروبنيوسي يقيس «مقداراً كلياً» يتضخّم بعدد البكسلات. أي تحليل ليبشيتز أو متانة لشبكة التفافية يجب أن يستخدم $\|C\|_2$؛ واستخدام $\|W\|_F$ في تنظيم الشبكات الالتفافية يعطي جزاءً يعتمد على دقة المدخل — وهو عيب معروف يفسّر الحاجة إلى إعادة ضبط المعامل عند تغيير دقة الصورة.

مثال (15-4.5): تراكم الخطأ عبر 24 طبقة — لماذا $\|W\|_2 \leq 1$ هو الأهم؟

المعطيات: $e_{l+1} = W_l e_l + \delta_l$ حيث $\|\delta_l\|_2 \leq \delta = 10^{-3}$ (خطأ تقريب/تكميم) و $\|W_l\|_2 = \gamma$ لكل l، و $L = 24$ طبقة، و $e_0 = 0$.

المطلوب: حدّ على $\|e_L\|_2$ كدالّة في γ، وقارن $\gamma = 1.2$ و $\gamma = 1.0$ و $\gamma = 0.9$.

الحل:

١. بالتوسيع المتكرّر: $e_L = \sum_{j=0}^{L-1} \left(\prod_{i=j+1}^{L-1} W_i\right) \delta_j$.

٢. بالتضاعف التحتي: $\|e_L\|_2 \leq \sum_{j=0}^{L-1} \gamma^{L-1-j}\, \delta = \delta \sum_{k=0}^{L-1} \gamma^k$.

٣. **الحالة** $\gamma = 1.2$: $\sum_{k=0}^{23} 1.2^k = \dfrac{1.2^{24} - 1}{0.2}$؛ و $1.2^{24} = e^{24 \times 0.182322} = e^{4.3757} = 79.50$ $\Longrightarrow$ المجموع $= \dfrac{78.50}{0.2} = 392.5$ $\Longrightarrow \|e_{24}\|_2 \leq 0.3925$.

٤. **الحالة** $\gamma = 1.0$: المجموع $= 24$ $\Longrightarrow \|e_{24}\|_2 \leq 0.024$.

٥. **الحالة** $\gamma = 0.9$: $\sum = \dfrac{1 - 0.9^{24}}{0.1} = \dfrac{1 - 0.0798}{0.1} = 9.202$ $\Longrightarrow \|e_{24}\|_2 \leq 0.0092$.

النتيجة: خطأ الإحداثي الواحد 10^{-3} يتضخّم إلى 0.3925 عند $\gamma = 1.2$ (معامل 392) مقابل 0.024 عند $\gamma = 1.0$ و 0.0092 عند $\gamma = 0.9$.

الربط بالذكاء الاصطناعي: هذه المتسلسلة الهندسية هي التحليل الكامل لتراكم الأخطاء في الشبكات العميقة — أخطاء التكميم (INT8/fb16)، وأخطاء الضغط، وأخطاء الحساب الموزّع. الاستنتاج العملي الحاسم: **إبقاء $\|W_l\|_2 \leq 1$ يحوّل التراكم من أُسّي إلى خطّي** ($L\delta$ بدلاً من $\gamma^L \delta$). وهذا بالضبط سبب شيوع التهيئة الوحدوية/المتعامدة (orthogonal initialization)، والتطبيع الطيفي، والقيود الصريحة $\|W\|_2 \leq 1$ في التدفّقات المقيَّدة (residual flows) والشبكات المتبقّية المقيَّدة.

4.4.5 أخطاء شائعة في النواظم المصفوفية

الخطأ الشائع	لماذا هو خطأ؟	التصحيح
استخدام $\|A\|_F$ بوصفه ثابت ليبشيتز	$\|I\|_2 = 1$ في حين أن $\|I\|_F = \sqrt{n}$	ثابت ليبشيتز هو $\|A\|_2$
افتراض التضاعف التحتي لناظم أقصى عنصر $\|A\|_{\max}$	مثال مضاد: $A = B = \mathbf{1}\mathbf{1}^\top$ (2×2) يعطي $\|AB\|_{\max} = 2 > 1$	استخدام نواظم مستحثة أو الفرونيوسي
استخدام $\rho(A) < 1$ شرطاً لـ «عدم الانفجار قصير المدى»	ρ يحكم السلوك **المقاربي** فقط؛ النمو العابر قد يكون ضخماً	افحص $\|A^k\|$ أيضاً (غيلفاند + النمو العابر)
ظنّ أن $\|A\|_2 = \rho(A)$	يصحّ للمصفوفات المتماثلة/الطبيعية فقط	للمصفوفات العامة: $\|A\|_2 = \sigma_1 \geq \rho(A)$
حساب $\|A\|_2$ بـ SVD في كل تكرار تدريب	تكلفة عالية؛ تكرار القوة بكفاءة كافية	استخدم تكرار القوة أو الحدود الرخيصة (23.5)
$\|A\|_\infty$ هو «أكبر مجموع **عمود**» و $\|A\|_1$ هو «أكبر مجموع **صف**»	التباس شائع جداً	تذكّر: $\|A\|_1$ يقترن بـ ℓ_1 ويجمع على الأعمدة
متسلسلة نيومان بشرط $\rho(A) < 1$ وحده لتقدير ناظم المعكوس	حدّ $\frac{1}{1-\|A\|}$ يتطلّب $\|A\| < 1$ بناظم **مستحث**	تحقّق من $\|A\| < 1$ لا من $\rho(A) < 1$
اعتبار رقم الحالة كبيراً «مجرد مسألة عددية»	هو خاصية **رياضية** للمسألة لا للخوارزمية	عالجه بالتنظيم/إعادة التصميم لا بدقة حسابية أعلى
اعتبار $\|A\|_\infty \leq \|A\|_2$	الاتجاه معكوس في العموم: قد يكون $\|A\|_\infty < \|A\|_2$ أو العكس	استخدم (23.5) للتحويل بينهما
$\|A\|_F$ لالتفاف مستقل عن حجم المدخل لكن ليس كذلك	يؤدي إلى معاملات تنظيم خاطئة عند تغيير الدقة	استخدم $\|C\|_2$ في التحليل واضبط التنظيم تبعاً لذلك

الفكرة في سطر: عائلة ℓ_p لم تتعامل مع المصفوفات بوصفها قوائم أرقام، بل بوصفها **مشغّلات** — بتطبيقها على **القيم المفردة** بدل الإحداثيات. فتولد عائلة **نواظم شاتن** $\|A\|_{S_p}$: S_1 = الناظم النووي (بديل الرتبة)، S_2 = الفرونيوسي، S_∞ = الطيفي. والمتراجحة الحاكمة التي تربط مصفوفتين هي **متراجحة فون نيومان**: الأثر الأعظم يحدث حين **تتطابق** محاور القيم المفردة.

1.5.5 الصياغة الرسمية

تعريف (نواظم شاتن — Schatten norms).

ليكن $A \in \mathbb{R}^{m\times n}$ بقيم مفردة $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ حيث $r = \operatorname{rank}(A)$. لأي $p \in [1,\infty]$:

$$\|A\|_{S_p} = \begin{cases} \left(\sum_{i=1}^{r} \sigma_i(A)^p\right)^{1/p}, & 1 \leq p < \infty \\ \sigma_1(A) = \|A\|_2, & p = \infty \end{cases} \tag{26.5}$$

والأعضاء الثلاثة الأهم:

$$\|A\|_{S_1} = \sum_i \sigma_i = \|A\|_* \text{ (النووي / trace norm)}, \qquad \|A\|_{S_2} = \sqrt{\textstyle\sum_i \sigma_i^2} = \|A\|_F, \qquad \|A\|_{S_\infty} = \sigma_1 = \|A\|_2$$

جدول رموز (26.5):

الرمز	المعنى	ملاحظات
p	أُسّ ناظم شاتن	$p \in [1,\infty]$
$\sigma_i(A)$	القيمة المفردة رقم i لـ A	مرتّبة تنازلياً، جذورُ القيم الذاتية لـ $A^\top A$
$r = \operatorname{rank}(A)$	رتبة المصفوفة = عدد القيم المفردة غير الصفرية	—
$\|A\|_{S_p}$	ناظم شاتن من الرتبة p	يُكتب أحياناً $\|A\|_p$ مع التمييز بالسياق
$\|A\|_{S_1} = \|A\|_*$	الناظم النووي (nuclear norm) / trace	**مجموع القيم المفردة؛ بديل مقعّب للرتبة**
$\|A\|_{S_2} = \|A\|_F$	الناظم الفرونيوسي	الحالة الوحيدة التي يتطابق فيها ناظم شاتن مع «ناظم القائمة»
$\|A\|_{S_\infty} = \|A\|_2$	الناظم الطيفي	أكبر قيمة مفردة
الرتابة في p	$1 \leq p \leq q \Rightarrow \|A\|_{S_p} \geq \|A\|_{S_q}$	معكوس رتابة ℓ_p ظاهرياً لأن العدد محدود بـ r
$\|A\|_{S_p}$ دالة على الطيف فقط	لا تعتمد على المتجهات المفردة	خاصية الثبات الوحدوي

نظرية (متراجحة فون نيومان للأثر — von Neumann).

لكل $A, B \in \mathbb{R}^{m\times n}$:

$$\left|\operatorname{tr}(A^\top B)\right| \;\le\; \sum_{i=1}^{\min(m,n)} \sigma_i(A)\,\sigma_i(B) \;=\; \big\langle \sigma(A),\, \sigma(B)\big\rangle \tag{27.5}$$

ويتحقّق التساوي (في القيمة المطلقة) إذا وفقط إذا كان لـ A و B **المتجهاتُ المفردة نفسها** (مع الترتيب والتوافق نفسه): أي $A = U\Sigma_A V^\top$ و $B = U\Sigma_B V^\top$ بالمصفوفتين الوحدويتين نفسيهما U, V.

جدول رموز (27.5):

الرمز	المعنى	ملاحظات
$\operatorname{tr}(\cdot)$	الأثر = مجموع القطر	الضرب الداخلي للمصفوفتين = $\operatorname{tr}(A^\top B) = \sum_{ij} A_{ij}B_{ij}$
$\|\operatorname{tr}(A^\top B)\|$	القيمة المطلقة للأثر	المقدار الذي نُقيّده
$\sigma_i(A), \sigma_i(B)$	القيم المفردة لكلتا المصفوفتين	**مرتّبتان تنازلياً** كلٌّ على حدة
$\sum_i \sigma_i(A)\sigma_i(B)$	الجداء التنازلي المتقابل	«أفضل ترتيب» — متراجحة إعادة الترتيب
$\langle \sigma(A), \sigma(B)\rangle$	الضرب الداخلي لشماعي القيم المفردة	الصيغة المختصرة
شرط التساوي	المحاور (المتجهات المفردة) متطابقة	U و V نفسيهما للمصفوفتين
U, V	المصفوفتان الوحدويتان في SVD	$U^\top U = I$، $V^\top V = I$
Σ_A, Σ_B	المصفوفتان القطريتان للقيم المفردة	عناصر قطرها σ_i
$\min(m,n)$	أصغر بُعدي المصفوفة = عدد القيم المفردة الممكنة	الحدّ الأعلى لعدد حدود الجداء

نظرية (هولدر لشاتن وازدواج النواظم المصفوفية).

ليكن p, q مترافقين ($\frac{1}{p}+\frac{1}{q}=1$). عندئذٍ:

$$\left|\operatorname{tr}(A^\top B)\right| \;\le\; \|A\|_2\,\|B\|_* \qquad \text{وخاصةً} \qquad \left|\operatorname{tr}(A^\top B)\right| \;\le\; \|A\|_{S_p}\,\|B\|_{S_q}, \tag{28.5}$$

والناظم الثنوي لناظم شاتن S_p هو S_q:

$$\big(\|\cdot\|_{S_p}\big)^* = \|\cdot\|_{S_q}, \qquad \|A\|_* \;=\; \max_{\|B\|_2\le 1} \operatorname{tr}(A^\top B), \qquad \|A\|_2 \;=\; \max_{\|B\|_*\le 1} \operatorname{tr}(A^\top B) \tag{29.5}$$

جدول رموز (28.5)–(29.5):

الرمز	المعنى	ملاحظات
p, q	أُسّان مترافقان	$1/p + 1/q = 1$
$\|A\|_{S_p}$	ناظم شاتن من الرتبة p لـ A	—
$\|B\|_{S_q}$	ناظم شاتن من الرتبة q لـ B	—
$\|A\|_2\|B\|_*$	الحالة $(p,q) = (\infty, 1)$	الأكثر استخداماً: طيفي × نووي
$\big(\|\cdot\|_{S_p}\big)^*$	الناظم الثنوي	يقابله S_q
$\max_{\|B\|_2\le 1} \operatorname{tr}(A^\top B)$	صيغة التعظيم للناظم النووي	يُحقّقها $B = UV^\top$ (مُجَمِّع الإشارات)
$\max_{\|B\|_*\le 1} \operatorname{tr}(A^\top B)$	صيغة التعظيم للناظم الطيفي	يُحقّقها $B = u_1 v_1^\top$
$UV^\top$	«مُجَمِّع الإشارات» (sign matrix) من SVD لـ A	$\operatorname{tr}(A^\top UV^\top) = \|A\|_*$ و $\|UV^\top\|_2 = 1$
$u_1 v_1^\top$	المكوّن المفرد الأول (رتبة 1)	σ_1 ويعطي $\|u_1 v_1^\top\|_* = 1$

نظرية (الثبات الوحدوي).

لكل مصفوفتين وحدويّتين $Q \in \mathbb{R}^{m\times m}$ و $R \in \mathbb{R}^{n\times n}$:

$$\|QAR^{\top}\|_{S_p} \;=\; \|A\|_{S_p} \quad \forall p \in [1,\infty]; \qquad \|A\|_{S_p} \text{ دالةٌ على القيم المفردة فقط} \tag{30.5}$$

نظرية (النووي بديلٌ مقعّب للرتبة، والرتبة الفعّالة).

على الكرة الطيفية $\{A : \|A\|_2 \le 1\}$، الناظم النووي هو **الغلاف المقعّب** (convex envelope) للرتبة. ويُقاس «التنائر الطيفي» بـ:

$$\|A\|_{*} \;\le\; \sqrt{r}\,\|A\|_F \quad\Longrightarrow\quad r \;\ge\; \frac{\|A\|_{*}^2}{\|A\|_F^2} \;=\; \operatorname{erank}(A) \tag{31.5}$$

جدول رموز (30.5)–(31.5):

الرمز	المعنى	ملاحظات
Q	مصفوفة وحدوية $m\times m$ $(Q^{\top}Q=I)$	تدوير في فضاء الخرج
R	مصفوفة وحدوية $n\times n$	تدوير في فضاء المدخل
$QAR^{\top}$	إعادةُ معلمة وحدوية للمصفوفة	لا تُغيّر أيّ ناظم شاتن
«الغلاف المقعّب»	أصغر دالة محدّبة تقلّ عن الدالة أو تساويها	يبرّر استخدام $\|\cdot\|_*$ بديلاً عن rank
$\{A : \|A\|_2 \le 1\}$	الكرة الطيفية	المجال الذي تُعرَّف عليه التغطية
$\operatorname{erank}(A)$	الرتبة الفعّالة (effective rank)	$= \|A\|_*^2/\|A\|_F^2 \in [1, r]$
$r \ge \operatorname{erank}$	الرتبة الفعّالة حدٌّ أدنى للرتبة	وهي مقياس مستمرّ (غير صحيح) للتعقيد الطيفي
$\sqrt{r}$	معامل التحويل النووي↔فرونيوسي	محكَم عند تساوي القيم المفردة

مبرّر الاستخدام: مسألة $\mathcal{A}(X) = b$ to subject min $\operatorname{rank}(X)$ (إكمال مصفوفة) هي صعبة-NP وغير محدّبة. الاسترخاء المقعّب الطبيعي هو $\mathcal{A}(X) = b$ to subject min $\|X\|_*$ — وهو برنامج محدّب قابل للحل. نظرية (31.5) والنتائج المرافقة (Candès–Recht، Candès–Tao) تضمن — تحت «عدم الترافق» (incoherence) وأخذ عيّنات كافية — أن الحلّين **يتطابقان**.

الشكل الهندسي: أفضل ترتيب للقيم المفردة هو التنازلي المتقابل؛ وأسوأ ترتيب هو المعكوس:

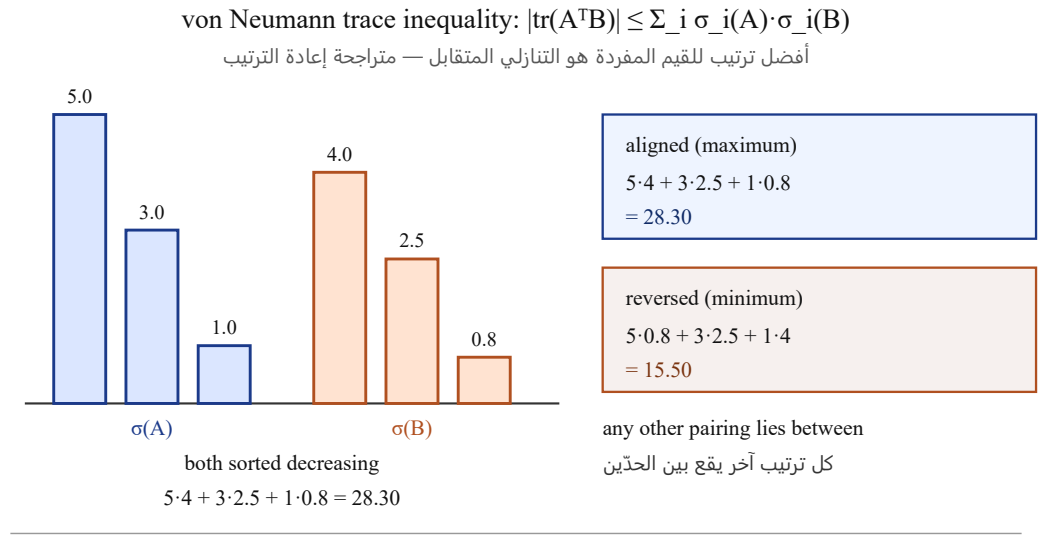
2.5.5 البرهان

برهان (27.5) — فون نيومان.

نكتب SVD: $A = U_A\Sigma_A V_A^{\top}$ و $B = U_B\Sigma_B V_B^{\top}$. بثبات الأثر تحت الدوران وبضرب الوحدويّات نردّ المسألة إلى:

$$\operatorname{tr}(A^{\top}B) = \operatorname{tr}\big(V_A\Sigma_A U_A^{\top}U_B\Sigma_B V_B^{\top}\big) = \operatorname{tr}\big(\Sigma_A Q \Sigma_B P^{\top}\big)$$

بوضع $Q = U_A^{\top}U_B$ و $P = V_A^{\top}V_B$ (وحدويّتان). نُثبت أولاً الحالة القطرية: ليكن $D_a = \operatorname{diag}(a_1 \ge \cdots \ge a_n \ge 0)$ و $D_b = \operatorname{diag}(b_1 \ge \cdots \ge b_n \ge 0)$، وليكن W وحدويّاً. عندئذٍ:



شكل ٥.٥: *
متراجحة فون نيومان للأثر وإعادة الترتيب

$$\operatorname{tr}(D_a W D_b W^\top) \;=\; \sum_{i,j} a_i b_j\, w_{ij}^2 \;=\; \sum_{i,j} a_i b_j\, m_{ij}$$

حيث $(w_{ij}^2) \;=\; M$ مصفوفة **مزدوجة العشوائية** (doubly stochastic): عناصرها غير سالبة ومجاميع صفوفها وأعمدتها $1 = (\text{لأن } WW^\top = W^\top W = I)$. مجال المصفوفات مزدوجة العشوائية هو **متعدّد أوجه بيركوف** الذي رؤوسه مصفوفات التباديل (نظرية بيركوف–فون نيومان). والدالة $M \;\mapsto\; \sum_{ij} a_i b_j m_{ij}$ خطّية، فتأخذ أعلاها على رأسٍ من الرؤوس، أي على مصفوفة تبديل Π:

$$\max_{W} \operatorname{tr}(D_a W D_b W^\top) \;=\; \max_{\Pi} \sum_i a_i\, b_{\pi(i)}$$

وبـ **متراجحة إعادة الترتيب** (rearrangement): أعظمُ قيمة لـ $\sum_i a_i b_{\pi(i)}$ مع a, b تنازليّين هي التبديل المطابق $\pi = \mathrm{id}$، أي $\sum_i a_i b_i$. إذن $|\operatorname{tr}(A^\top B)| \le \sum_i \sigma_i(A)\sigma_i(B)$. ■

برهان (28.5) — هولدر لشاتن.

من فون نيومان ثم هولدر العادي على شماعي القيم المفردة:

$$|\operatorname{tr}(A^\top B)| \;\le\; \sum_i \sigma_i(A)\sigma_i(B) \;\le\; \Big(\sum_i \sigma_i(A)^p\Big)^{1/p} \Big(\sum_i \sigma_i(B)^q\Big)^{1/q} \;=\; \|A\|_{S_p} \|B\|_{S_q}$$

وحالة $(p, q) = (\infty, 1)$ تعطي $|\operatorname{tr}(A^\top B)| \le \sigma_1(A) \sum_i \sigma_i(B) = \|A\|_2 \|B\|_*$. ■

برهان (29.5) — الازدواج.

من (28.5): $\operatorname{tr}(A^\top B) \le \|A\|_{S_p}\|B\|_{S_q}$ لكل B، فيكون الثنوي $\|A\|_{S_q} \le$. ولإثبات التساوي نختار B بمحاورَ مطابقةٍ لمحاور A: إن كان $A = U\Sigma_A V^\top$ نأخذ $B = U\Sigma_B V^\top$ بـ $\sigma_i(B) = \sigma_i(A)^{q-1}/\|A\|_{S_q}^{q-1}$؛ فـ $\|B\|_{S_p} = 1$ و $\operatorname{tr}(A^\top B) = \sum_i \sigma_i(A)\sigma_i(B) = \|A\|_{S_q}$ (تحقّق مباشر بـ $(q-1)p = q$). وحالة النووي: $B = UV^\top$ يعطي $\|B\|_2 = 1$ و $\operatorname{tr}(A^\top UV^\top) = \operatorname{tr}(V\Sigma_A U^\top UV^\top) = \operatorname{tr}(\Sigma_A) = \|A\|_*$. ✓ ■

برهان (30.5).

القيم المفردة لـ $QAR^\top$: بما أن Q, R وحدويّتان، فإن $(QAR^\top)^\top(QAR^\top) = RA^\top AR^\top$ — وهي مشابهة وحدوياً لـ $A^\top A$، فلهما القيم الذاتية نفسها، ومن ثم القيم المفردة نفسها. فكل ناظم شاتن (دالة على القيم المفردة فقط) ثابت. ■

برهان (31.5).

بكوشي–شفارتس على شماع القيم المفردة غير الصفرية (عددها r):

$$\|A\|_* = \sum_{i=1}^{r} \sigma_i \cdot 1 \;\le\; \sqrt{\sum_{i=1}^{r} \sigma_i^2}\,\sqrt{r} \;=\; \sqrt{r}\,\|A\|_F$$

وبالتربيع وإعادة الترتيب: $r \ge \|A\|_*^2/\|A\|_F^2$. وكون $\|\cdot\|_*$ هو الغلاف المقعّب لـ rank على الكرة الطيفية نتيجةٌ كلاسيكية (Fazel 2002؛ Recht–Fazel–Parrilo 2010) ونكتفي بالإحالة إليها. ■

3.5.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-5.5): حساب نواظم شاتن الأربعة لمصفوفة واحدة

المعطيات: مصفوفة A قيمها المفردة $\sigma(A) = (3.5,\ 2.1,\ 0.4)$.
المطلوب: احسب $\|A\|_{S_1}$ و $\|A\|_{S_2}$ و $\|A\|_{S_4}$ و $\|A\|_{S_\infty}$، وتحقّق من الرتابة في p.
الحل:

١. $\|A\|_{S_1} = \|A\|_* = 3.5 + 2.1 + 0.4 = 6.0$.

٢. $\|A\|_{S_2} = \|A\|_F = \sqrt{12.25 + 4.41 + 0.16} = \sqrt{16.82} = 4.1012$.

٣. $\|A\|_{S_4} = \left(3.5^4 + 2.1^4 + 0.4^4\right)^{1/4} = \left(150.0625 + 19.4481 + 0.0256\right)^{1/4} = (169.536)^{1/4} = 3.6084$.

٤. $\|A\|_{S_\infty} = \|A\|_2 = \sigma_1 = 3.5$.

٥. الرتابة: $3.5 \le 3.6084 \le 4.1012 \le 6.0$ ✓ — كلما كبر p صغر الناظم (عكس عائلة ℓ_p على المتجهات ظاهرياً).

النتيجة: $\|A\|_2 = 3.5$، $\|A\|_{S_4} = 3.6084$، $\|A\|_F = 4.1012$، $\|A\|_* = 6.0$.

الربط بالذكاء الاصطناعي: الناظم النووي يعاقب **مجموع** القيم المفردة فيدفع نحو الرتبة المنخفضة؛ والناظم الطيفي يعاقب **أكبرها** فقط فيدفع نحو «تسطيح» الطيف. اختيار p يحدّد أيّ نمط بنيوي تفضّله: $p = 1$ للرتبة المنخفضة، و $p = \infty$ للاستقرار/ليبشيتز، و $p = 2$ للطول الكلي (تنظيم decay weight المعتاد).

مثال (5.5-2): الناظم النووي بديلاً مقعّباً للرتبة في إكمال مصفوفة

المعطيات: مصفوفة تقييمات 4×4 ناقصة. اقترح المُحلّل إكمالين متوافقين مع المشاهَدات:

- X_1 بطيف مفرد $\sigma = (12,\ 3,\ 0.5,\ 0.2)$؛
- X_2 بطيف مفرد $\sigma = (6,\ 5,\ 4.8,\ 4.5)$.

المطلوب: أيّهما يختار مُصغِّر الناظم النووي؟ وما «الرتبة الفعّالة» لكل منهما؟

الحل:

١. $\|X_1\|_* = 12 + 3 + 0.5 + 0.2 = 15.7$.

٢. $\|X_2\|_* = 6 + 5 + 4.8 + 4.5 = 20.3$.

٣. إذن يُختار X_1 (ناظمه النووي أصغر).

٤. $\|X_1\|_F = \sqrt{144 + 9 + 0.25 + 0.04} = \sqrt{153.29} = 12.381$، $\operatorname{erank}(X_1) = \dfrac{15.7^2}{153.29} = \dfrac{246.49}{153.29} = 1.608$.

٥. $\|X_2\|_F = \sqrt{36 + 25 + 23.04 + 20.25} = \sqrt{104.29} = 10.212$، $\operatorname{erank}(X_2) = \dfrac{412.09}{104.29} = 3.951$.

٦. لاحظ أن $\|X_1\|_F > \|X_2\|_F$ — فلو استخدمنا تنظيماً فرونيوسياً لاخترنا X_2 (الأقلّ ناظماً فرونيوسياً) وهو **الأعلى رتبة فعّالة**.

النتيجة: مُصغِّر الناظم النووي يختار X_1 برتبة فعّالة 1.61، بينما التنظيم الفرونيوسي يختار X_2 برتبة فعّالة 3.95.

الربط بالذكاء الاصطناعي: هذا هو الفرق الحاسم في أنظمة التوصية (مصفوفة المستخدم–العنصر ناقصة بشدة): تصغير الرتبة يفترض أن التفضيلات محكومة بعدد قليل من العوامل الكامنة؛ والاسترخاء المقعّب $\|X\|_*$ هو البديل القابل للحل. أمّا التنظيم الفرونيوسي فلا «يرى» الرتبة إطلاقاً — فهو يقيس الطول الإجمالي لا توزيعه على الطيف.

مثال (5.5-3): تحقّق عددي من متراجحة فون نيومان بثلاثة ترتيبات

المعطيات: $A = \mathrm{diag}(4,\ 2.5,\ 1)$ وثلاثُ مصفوفات B بالقيم المفردة نفسها $\sigma(B) = (3,\ 2,\ 0.5)$ بترتيبات مختلفة: $B_1 = \mathrm{diag}(3,\ 2,\ 0.5)$ (مطابق)، و $B_2 = \mathrm{diag}(2,\ 3,\ 0.5)$ (مبدَّل جزئياً)، و $B_3 = \mathrm{diag}(0.5,\ 2,\ 3)$ (معكوس).

المطلوب: احسب $\mathrm{tr}(A^\top B_k)$ لكلٍّ منها وقارن بسقف فون نيومان.

الحل:

١. السقف: $\sum_i \sigma_i(A)\sigma_i(B) = 4 \times 3 + 2.5 \times 2 + 1 \times 0.5 = 12 + 5 + 0.5 = 17.5$.

٢. B_1 (مطابق): $\mathrm{tr}(A^\top B_1) = 4 \times 3 + 2.5 \times 2 + 1 \times 0.5 = 17.5$ — **يبلغ السقف** ✓ (شرط التساوي: المحاور متطابقة).

٣. B_2: $4 \times 2 + 2.5 \times 3 + 1 \times 0.5 = 8 + 7.5 + 0.5 = 16.0 \le 17.5$ ✓.

٤. B_3 (معكوس): $4 \times 0.5 + 2.5 \times 2 + 1 \times 3 = 2 + 5 + 3 = 10.0 \le 17.5$ ✓، وهو **الأدنى** (متراجحة إعادة الترتيب).

النتيجة: 17.5 (أقصى) $\ge 16.0 \ge 10.0$ (أدنى)، وكلها داخل سقف فون نيومان 17.5.

الربط بالذكاء الاصطناعي: القيمة $\mathrm{tr}(A^\top B)$ هي الضرب الداخلي بين مصفوفتين — وتظهر بوصفها «تشابهاً» في مقارنة الأوزان بين نموذجين (linear mode connectivity، دمج النماذج). متراجحة فون نيومان تقول: **التشابه الأقصى يتحقّق حين تتطابق المحاور المفردة، لا حين تتطابق القيم المفردة وحدها.** ولهذا تقيس بحوث دمج النماذج «محاذاةً» (alignment) قبل الجمع، لا مجرد تطابق الأطياف.

مثال (5.5-4): هندسة المحاذاة — من الأثر الأقصى إلى الأدنى بتدوير واحد

المعطيات: $A = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$ و $B = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}$. نُدوِّر B بزاوية $45°$: $B_\theta = QBQ^\top$ حيث $Q = \begin{pmatrix} c & -s \\ s & c \end{pmatrix}$ و $c = s = \frac{1}{\sqrt{2}}$.

المطلوب: احسب $\mathrm{tr}(A^\top B_\theta)$ وقارنه بالأقصى والأدنى الممكنين.

الحل:

١. الأقصى (محاور مطابقة): $\mathrm{tr}(A^\top B) = 3 \times 2 + 1 \times 0.5 = 6.5$.

٢. الأدنى (محاور معكوسة، أي B بترتيب $(0.5, 2)$): $\mathrm{tr} = 3 \times 0.5 + 1 \times 2 = 3.5$.

٣. الحساب: $B_\theta = \begin{pmatrix} 2c^2 + 0.5s^2 & 1.5cs \\ 1.5cs & 2s^2 + 0.5c^2 \end{pmatrix} = \begin{pmatrix} 1.25 & 0.75 \\ 0.75 & 1.25 \end{pmatrix}$.

٤. $\mathrm{tr}(A^\top B_\theta) = 3 \times 1.25 + 1 \times 1.25 = 3.75 + 1.25 = 5.0$.

٥. التحقّق: $3.5 \le 5.0 \le 6.5$ ✓.

٦. الثبات: $\|B_\theta\|_{S_p} = \|B\|_{S_p}$ لكل p (وحدويّة Q) — التدوير غيّر الأثر لا الناظم.

النتيجة: الأثر تراوح بين 3.5 و 6.5 حسب زاوية المحاور، بينما ناظم شاتن لم يتغيّر إطلاقاً.

الربط بالذكاء الاصطناعي: الرسالة: **الناظم يحمي «المقدار»، والمحاذاة تحدّد «التفاعل».** حين تُدمج تحديثات (مثل LoRA أو task vectors) فإن مقدار النتيجة يعتمد على زاوية المحاور المفردة بينها؛ وتجاهل ذلك يفسّر لماذا تبدو بعض عمليات الدمج «معجزة» وأخرى «كارثة» بالأوزان نفسها.

مثال (5-5.5): الناظم النووي لتحديث LoRA من رتبة r

المعطيات: تحديث منخفض الرتبة $\Delta W = u_1 v_1^\top + u_2 v_2^\top$ بمتجهات متعامدة: $\|u_1\|_2 = 1.8$، $\|v_1\|_2 = 2.2$، $\|u_2\|_2 = 1.1$، $\|v_2\|_2 = 1.5$.

المطلوب: قيم ΔW المفردة ونواظمه الثلاثة.

الحل:

١. كل حدّ $u_k v_k^\top$ رتبته 1 وقيمته المفردة الوحيدة $\|u_k\|_2 \|v_k\|_2$.

٢. بشرط التعامد ($u_1 \perp u_2$ و $v_1 \perp v_2$): طيف ΔW هو الاتحاد $= \{1.8 \times 2.2,\ 1.1 \times 1.5\} = \{3.96,\ 1.65\}$.

٣. $\|\Delta W\|_* = 3.96 + 1.65 = 5.61$.

٤. $\|\Delta W\|_F = \sqrt{15.6816 + 2.7225} = \sqrt{18.4041} = 4.2900$.

٥. $\|\Delta W\|_2 = 3.96$.

٦. التحقّق: $3.96 \le 4.2900 \le 5.61$ ✓.

النتيجة: $\sigma(\Delta W) = (3.96,\ 1.65)$، $\|\Delta W\|_* = 5.61$، $\|\Delta W\|_F = 4.290$، $\|\Delta W\|_2 = 3.96$.

الربط بالذكاء الاصطناعي: تحديث LoRA برتبة r له **على الأكثر** r قيمة مفردة غير صفرية — فالناظم النووي يصير مقياساً مباشراً لـ «مقدار التعديل» يُناسب الرتبة. ولأن $\|\Delta W\|_*$ هو البديل المقعّب للرتبة، فإن مراقبته أثناء الضبط الدقيق تكشف متى «يتضخّم» التحديث فعلياً مقابل متى يبقى محصوراً في اتجاهات قليلة — وهذا بالضبط ما يُراد من الضبط منخفض الرتبة.

مثال (6-5.5): الرتبة الفعّالة حدّاً أدنى للرتبة الحقيقية

المعطيات: مصفوفة A بـ $\|A\|_* = 12$ و $\|A\|_F = 4$.

المطلوب: حدّ أدنى لرتبة A، وبيان متى يُبلَغ هذا الحدّ.

الحل:

١. الصيغة (31.5): $r \ge \dfrac{\|A\|_*^2}{\|A\|_F^2} = \dfrac{144}{16} = 9$.

٢. إذن $\operatorname{rank}(A) \ge 9$.

٣. متى يُبلَغ الحدّ؟ الشرط اللازم للتساوي في كوشي–شفارتس المستخدمة في البرهان هو تساوي كل القيم المفردة غير الصفرية.

٤. لو كان $r = 9$ فعلاً لكانت كل القيم المفردة $1.\overline{3}$؛ $\frac{\|A\|_*}{9} = \frac{12}{9} = 1.\overline{3}$؛ والتحقّق: $\|A\|_F = \sqrt{9 \times (1.\overline{3})^2} = \sqrt{9 \times 1.7778} = \sqrt{16} = 4$ ✓.

٥. لو كان الطيف مركّزاً (مثلاً $\sigma = (3.9, 0.5, 0.5, \dots)$) لكانت الرتبة أكبر بكثير من 9 مع الناظمين أنفسهما تقريباً.

النتيجة: $r \geq 9$، والحدّ مُحكَم عند الطيف المسطّح.

الربط بالذكاء الاصطناعي: الرتبة الفعّالة $\text{erank} = \|A\|_*^2 / \|A\|_F^2$ مقياسٌ مستمرّ (غير صحيح) لـ «عدد الاتجاهات المهمّة فعلاً». وهي أداة تشخيص يومية: للجاكوبي، للتدرّجات، لمصفوفات التمثيل. قيمتها لا تحتاج إلا إلى الناظمين النووي والفرونيوسي، ولا تحتاج إلى حساب الرتبة نفسها (وهي كمية غير متصلة وحسّاسة للضجيج).

مثال (5.5-7): هولدر لشاتن $(p, q) = (\infty, 1)$ — متى يتفوّق على كوشي–شفارتس الفرونيوسي؟

المعطيات: تحديث أوزان منخفض الرتبة $\Delta W \in \mathbb{R}^{64 \times 64}$ بطيف مفرد $\sigma = (1.5, 1.0, 0.7)$ والباقي صفر؛ ومدخل X بـ $\|X\|_2 = 2.8$ و $\|X\|_F = 12$.

المطلوب: حدّان على التغيّر $\langle \Delta W, X \rangle = \text{tr}(\Delta W^\top X)$: أحدهما بهولدر لشاتن والآخر بكوشي–شفارتس الفرونيوسي.

الحل:

١. $\|\Delta W\|_* = 1.5 + 1.0 + 0.7 = 3.2$؛ و $\|\Delta W\|_F = \sqrt{2.25 + 1 + 0.49} = \sqrt{3.74} = 1.9339$.

٢. حدّ هولدر لشاتن $(p, q) = (\infty, 1)$: $|\langle \Delta W, X \rangle| \leq \|\Delta W\|_* \|X\|_2 = 3.2 \times 2.8 = 8.96$.

٣. حدّ كوشي–شفارتس الفرونيوسي: $|\langle \Delta W, X \rangle| \leq \|\Delta W\|_F \|X\|_F = 1.9339 \times 12 = 23.21$.

٤. المقارنة: $8.96 < 23.21$ — حدّ شاتن أحكم بـ 2.59 مرة.

النتيجة: $|\langle \Delta W, X \rangle| \leq 8.96$ بهولدر لشاتن، مقابل ≤ 23.21 بكوشي–شفارتس الفرونيوسي.

الربط بالذكاء الاصطناعي: القاعدة العامة: **إذا كان أحد الطرفين منخفض الرتبة، استخدم $(\infty, 1)$: نووي × طيفي.** السبب أن الناظم النووي «يلتقط» أن ΔW يؤثّر في ثلاثة اتجاهات فقط، في حين أن $\|X\|_F = 12$ يفترض أن كل الاتجاهات الـ 4096 نشطة. هذا الحدّ هو ما يُستخدم في تحليل استقرار الضبط الدقيق منخفض الرتبة وتحديثات المحوّلات.

مثال (5.5-8): قرار القطع في تقريب من رتبة منخفضة — كم مكوّناً نحتفظ به؟

المعطيات: مصفوفة أوزان A بطيف مفرد $\sigma = (8, 6, 5, 1, 0.9, 0.8, 0.7, 0.6)$.

المطلوب: احسب الرتبة الفعّالة، ثم خطأ القطع (الفرونيوسي النسبي) عند $k = 3$ و $k = 4$، وقرّر.

الحل:

١. $\|A\|_* = 8 + 6 + 5 + 1 + 0.9 + 0.8 + 0.7 + 0.6 = 23.0$.

٢. $\|A\|_F^2 = 64 + 36 + 25 + 1 + 0.81 + 0.64 + 0.49 + 0.36 = 128.30 \Rightarrow \|A\|_F = 11.327$.

٣. $\operatorname{erank}(A) = \dfrac{23.0^2}{128.30} = \dfrac{529}{128.30} = 4.123 \Rightarrow$ الرتبة الفعّالة ≈ 4 من أصل 8.

٤. القطع عند $k = 3$: خطأ فروبنيوسي $= \sqrt{1 + 0.81 + 0.64 + 0.49 + 0.36} = \sqrt{3.30} = 1.8166$؛ نسبياً $= \dfrac{1.8166}{11.327} = 16.0\%$.

٥. القطع عند $k = 4$: الخطأ $= \sqrt{0.81 + 0.64 + 0.49 + 0.36} = \sqrt{2.30} = 1.5166$؛ نسبياً 13.4%.

٦. القطع عند $k = 3$ حذف مكوّناً مقدارُه 1 (من 23) فكلّف 2.6 نقطة مئوية إضافية.

النتيجة: الرتبة الفعّالة 4.12 تشير إلى الاحتفاظ بـ 4 مكوّنات، والقطع عند 3 يكلّف 16% خطأً مقابل 13.4% عند 4.

الربط بالذكاء الاصطناعي: الرتبة الفعّالة هي «مؤشّر أوّلي» سريع لاختيار رتبة الضغط قبل حساب منحنى الخطأ الكامل: ابدأ من $k \approx \operatorname{erank}$ ثم اضبط بحسب ميزانية الدقة. وهي أيضاً مقياس «كم معلومة» تحتويها المصفوفة فعلاً — أدقّ بكثير من الرتبة الصحيحة التي تقفز من 8 إلى 8 بلا إنذار عن اقتراب المصفوفة من الرتبة المنخفضة.

مثال (5.5-9): الثبات الوحدوي — لماذا تنظيم فروبنيوسي مستقل عن إعادة المعلمة؟

المعطيات: $W = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}$، ونُدوّرها بزاوية $45°$: $W' = QWQ^\top$ بـ $Q = \begin{pmatrix} c & c \\ c & -c \end{pmatrix}$ و $c = \frac{1}{\sqrt{2}}$.

المطلوب: قارن النواظم الشاتنية والناظم الإحداثي ℓ_1 قبل التدوير وبعده.

الحل:

١. $W' = 2\,u_1 u_1^\top + 0.5\,u_2 u_2^\top$ حيث $u_1 = (c,\, c)$ و $u_2 = (c,\, -c)$:

$$W' = 2\begin{pmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{pmatrix} + 0.5\begin{pmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{pmatrix} = \begin{pmatrix} 1.25 & 0.75 \\ 0.75 & 1.25 \end{pmatrix}$$

٢. $\|W\|_F = \sqrt{4 + 0.25} = \sqrt{4.25} = 2.0616$؛ و $\|W'\|_F = \sqrt{1.5625 + 0.5625 + 0.5625 + 1.5625} = \sqrt{4.25} = 2.0616$ ✓ **متساويان.**

٣. $\|W\|_* = 2.5 = \|W'\|_*$ ✓، و $\|W\|_2 = 2 = \|W'\|_2$ ✓ (القيم المفردة نفسها $(2,\, 0.5)$).

٤. الناظم الإحداثي ℓ_1: $\|\operatorname{vec}(W)\|_1 = 2 + 0.5 = 2.5$؛ و $\|\operatorname{vec}(W')\|_1 = 1.25 + 0.75 + 0.75 + 1.25 = 4.0$ × **مختلفان** بمعامل 1.6.

النتيجة: نواظم شاتن (ومنها الفروبنيوسي) ثابتة تحت التدوير الوحدوي، أمّا التنظيم الإحداثي ℓ_1 فليس كذلك.

الربط بالذكاء الاصطناعي: لهذا يُقال إن تنظيم $\|W\|_F$ (weight decay) «غير متأثّر بإعادة المعلمة الوحدوية» — وهي خاصية مرغوبة تجعل الجزاء متسقاً مع هندسة المشغّل. أمّا التنظيم الإحداثي ℓ_1 (الذي يُستخدم للتناثر) فهو

يعتمد على المحاور: سيعاقب التمثيل نفسه بقيم مختلفة بعد أي تدوير. هذا يفسّر لماذا لا ينتج decay weight تناثراً بالمعنى الهندسي، بينما ينتجه تنظيم ℓ_1 الإحداثي (لكن بمحاور ثابتة يفرضها التمثيل).

مثال (5.5-10): فون نيومان مقابل كوشي–شفارتس الفرونيوسي على مصفوفتين متوازيتين

المعطيات: W_1 بطيف $\sigma = (5,\ 4,\ 3)$ و W_2 بطيف $\sigma = (4.5,\ 3.5,\ 2)$، ومحاورهما المفردة **متطابقة تماماً**.
المطلوب: احسب $\langle W_1, W_2 \rangle$ وقارن الحدّين.
الحل:

١. بالمحاذاة التامة: $\langle W_1, W_2 \rangle = \operatorname{tr}(W_1^\top W_2) = 5 \times 4.5 + 4 \times 3.5 + 3 \times 2 = 22.5 + 14 + 6 = 42.5$.

٢. حدّ فون نيومان: $\sum_i \sigma_i(W_1)\sigma_i(W_2) = 42.5$ — **مساوٍ تماماً** (لأن المحاور متطابقة) ✓.

٣. $\|W_1\|_F = \sqrt{25 + 16 + 9} = \sqrt{50} = 7.0711$؛ $\|W_2\|_F = \sqrt{20.25 + 12.25 + 4} = \sqrt{36.5} = 6.0415$.

٤. حدّ كوشي–شفارتس الفرونيوسي: $7.0711 \times 6.0415 = 42.72$.

٥. المقارنة: $42.5 \le 42.5 \le 42.72$ — فون نيومان **مُحكَم** هنا، وكوشي–شفارتس فضفاض بـ 0.22.

النتيجة: فون نيومان يعطي 42.5 (**مُحكَماً**) مقابل 42.72 لكوشي–شفارتس الفرونيوسي.
الربط بالذكاء الاصطناعي: متراجحة فون نيومان هي «كوشي–شفارتس الدقيقة» لفضاء المصفوفات: فهي تستثمر معرفة **المحاور** لا الأطوال وحدها. في تحليل «الترابط الخطي في الأوزان» (linear connectivity mode) بين نموذجين مضبوطين من أصل واحد، تكون المحاور شبه متطابقة، فتكون فون نيومان مُحكمة تقريباً — وهذا يمنح حدوداً أدقّ بكثير على مسافة الأوزان بين النموذجين.

مثال (5.5-11): تحقّق صريح من صيغة الثنوي $\|A\|_* = \max_{\|B\|_2 \le 1} \operatorname{tr}(A^\top B)$
المعطيات: $A = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ (متماثلة موجبة التحديد).
المطلوب: ابحث $B^\star$ بالشرط $\|B\|_2 \le 1$ التي تُعظّم $\operatorname{tr}(A^\top B)$، وتحقّق أن القيمة العظمى $= \|A\|_*$.
الحل:

١. تحليل A الطيفي: $A = Q\,\operatorname{diag}(4,2)Q^\top$ بـ $Q = \begin{pmatrix} c & c \\ c & -c \end{pmatrix}$ و $c = \frac{1}{\sqrt{2}}$ (تحقّق: $4\begin{pmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{pmatrix} + 2\begin{pmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{pmatrix} = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ ✓).

٢. القيم المفردة $(4, 2) \Rightarrow \|A\|_* = 6$ و $\|A\|_2 = 4$.

٣. المُعظِّم في (29.5) هو «مُجمِّع الإشارات» $B^\star = UV^\top$. وبما أن $A \succeq 0$ فإن $U = V = Q \Rightarrow B^\star = I$.

٤. التحقّق من الشرط: $\|B^\star\|_2 = \|I\|_2 = 1$ ✓.

٥. القيمة: $\|A\|_* = 6 = 3 + 3 = \operatorname{tr}(A) = \operatorname{tr}(A^\top I)$ ✓.

٦. تحقّق إضافي بـ $B = -I$: $\operatorname{tr}(A^\top(-I)) = -6$ (القيمة الدنيا)؛ وأي B آخر بـ $\|B\|_2 \le 1$ يعطي قيمةً في $[-6, 6]$.

النتيجة: $B^\star = I$ و $\|A\|_* = 6 = \max$ — صيغة الثنوي مؤكَّدة.

الربط بالذكاء الاصطناعي: صيغة الثنوي هذه هي التي تُنتج «شهادة المزدوج» (dual certfiicate) في مسائل إكمال المصفوفة وتقليل الرتبة: لإثبات أن A هو الحل الأمثل، يكفي إيجاد مصفوفة B بـ $\|B\|_2 \le 1$ تحقّق $\|A\|_* = \operatorname{tr}(A^\top B)$ (وشروطاً على المدى). هذه التقنية نفسها تظهر في تحليل الاسترخاء المحدّب لتدريب الشبكات (الجزء السابع).

مثال (5.5-12): دون جمعيّة الناظم النووي — متى تكون متساوية ومتى صارمة؟

المعطيات: حالتان على $\mathbb{R}^{2\times 2}$:

- (أ) $A = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}$ و $B = \begin{pmatrix} 0 & 0 \\ 0 & 3 \end{pmatrix}$ (دعمان متعامدان).
- (ب) $A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ و $B = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$ (دعمان متداخلان).

المطلوب: تحقّق من $\|A + B\|_* \le \|A\|_* + \|B\|_*$ وحدّد متى تكون المساواة.
الحل:

١. الحالة (أ): $\|A\|_* = 2$، $\|B\|_* = 3$، $A + B = \operatorname{diag}(2, 3) \Rightarrow \|A + B\|_* = 5 = 2 + 3$ — **مساواة.**

٢. الحالة (ب): $\|A\|_* = 2$، $\|B\|_* = 2$، $A + B = \operatorname{diag}(2, 0) \Rightarrow \|A + B\|_* = 2 < 4$ — **متراجحة صارمة.**

٣. القاعدة: المساواة تتحقّق عندما تكون «المساحات المفردة» (المدى ومدى المنقول) متعامدة — أي أن طيف المجموع هو **اتحاد** الطيفين.

٤. تطبيق على الكل: لو كانت A محصورة في الكتلة $(1:2,\ 1:2)$ و B في الكتلة $(3:4,\ 3:4)$ من مصفوفة 4×4 لكان $\|A + B\|_* = \|A\|_* + \|B\|_*$ تماماً.

النتيجة: $\|A + B\|_* \le \|A\|_* + \|B\|_*$؛ مساواةٌ عند تعامد الدعمين، وصارمةٌ عند التداخل.

الربط بالذكاء الاصطناعي: هذه الخاصية تفسّر سلوك «حساب المهام» (task arithmetic) عند دمج تحديثات LoRA محصورة في كتل مختلفة: الناظم النووي للنتيجة = مجموع النواظم، فلا «تداخل» يُفقد. أمّا إذا تداخلت الكتل فقد يكون المجموع أقصر بكثير من مجموع الأجزاء (تداخل هدّام) — وقياس الناظم النووي للنتيجة مقابل مجموع نواظم الأجزاء مؤشّر كمّي مباشر لمدى التداخل.

مثال (5.5-13): الناظم النووي لمصفوفة شبه موجبة = الأثر (بلا SVD!)

المعطيات: مصفوفة غرام/نواة $K \succeq 0$ قيمها الذاتية $(12,\ 5,\ 3,\ 1,\ 0.5)$.
المطلوب: احسب $\|K\|_*$ و $\|K\|_F$ والرتبة الفعّالة — دون حساب قيم مفردة.
الحل:

١. لأن $K \succeq 0$: كل القيم الذاتية غير سالبة، والقيم المفردة = القيم الذاتية $\Longrightarrow \|K\|_* = \sum_i \lambda_i = \operatorname{tr}(K)$.

٢. $\|K\|_* = 12 + 5 + 3 + 1 + 0.5 = 21.5$.

٣. $\|K\|_F = \sqrt{144 + 25 + 9 + 1 + 0.25} = \sqrt{179.25} = 13.385$.

٤. $\operatorname{erank}(K) = \dfrac{21.5^2}{179.25} = \dfrac{462.25}{179.25} = 2.579$.

٥. $\|K\|_2 = \lambda_{\max} = 12$.

النتيجة: $\|K\|_* = \operatorname{tr}(K) = 21.5$، $\|K\|_F = 13.385$، والرتبة الفعّالة 2.58 من أصل 5.
الربط بالذكاء الاصطناعي: «النووي = الأثر» للمصفوفات شبه الموجبة يجعل النووي **رخيصاً جداً** في حالات مهمّة: مصفوفات الغرام، مصفوفات النواة، مصفوفات التغاير، ومصفوفات فيشر للمعلومات. في كل هذه الحالات يصير قياس الرتبة الفعّالة مجرد نسبة بين الأثر ومجموع مربّعات القيم الذاتية — بلا SVD. ويُستخدم ذلك في مراقبة «مدى استغلال» فضاء التمثيل في الشبكات.

مثال (5.5-14): الرتبة الفعّالة للتدرّج — تشخيص توقّف المُحسِّن

المعطيات: طيف تدرّج G في بداية التدريب: $\sigma = (10,\ 8,\ 7,\ 6,\ 5,\ 4,\ 3,\ 2)$. وفي مرحلة لاحقة: $\sigma = (18,\ 3,\ 2,\ 1.5,\ 1,\ 0.8,\ 0.6,\ 0.4)$.
المطلوب: احسب $\|G\|_F$ والرتبة الفعّالة في الحالتين وفسّر.
الحل:

١. الحالة الأولى: $\|G\|_* = 45$؛ $\|G\|_F^2 = 100 + 64 + 49 + 36 + 25 + 16 + 9 + 4 = 303 \Longrightarrow$ $\|G\|_F = 17.407$؛ $\operatorname{erank} = \dfrac{2025}{303} = 6.683$.

٢. الحالة الثانية: $\|G\|_* = 18 + 3 + 2 + 1.5 + 1 + 0.8 + 0.6 + 0.4 = 27.3$؛ $\|G\|_F^2 = 324 + 9 + 4 + 2.25 + 1 + 0.64 + 0.36 + 0.16 = 341.41 \Longrightarrow \|G\|_F = 18.477$؛ $\operatorname{erank} = \dfrac{745.29}{341.41} = 2.183$.

٣. المقارنة: $\|G\|_F$ **ازداد** قليلاً ($17.41 \rightarrow 18.48$، أي $+6\%$)؛ لكن الرتبة الفعّالة **انهارت** من 6.68 إلى 2.18 (-67%).

النتيجة: التدرّج صار «أثقل» قليلاً لكنه محصور في اتجاهين اثنين بدل سبعة.
الربط بالذكاء الاصطناعي: هذا نمط فشل كلاسيكي: الناظم الكلي للتدرّج لا يتغيّر كثيراً فيبدو التدريب «حيّاً»، لكن التحديثات كلها تتجمّع في اتجاهين فقط فتتوقّف القدرة على استكشاف بقيّة الفضاء. وهو أيضاً سبب نجاح طرق

الضغط المتناثر والتكميم في التدريب الموزّع: التدرّج **فعلياً** منخفض الرتبة وإن لم يكن كذلك صراحةً. مؤشّر الرتبة الفعّالة يكشف ذلك بجُهد حسابي لا يُذكر مقابل SVD كاملة.

مثال (5.5-15): كشف انهيار التمثيل في التعلّم المتناقض بالرتبة الفعّالة

المعطيات: مصفوفة تغاير تمثيلات $C \in \mathbb{R}^{8\times 8}$ (شبه موجبة). قبل الانهيار: قيم ذاتية $(8,\ 6,\ 5,\ 4,\ 3,\ 2,\ 1.5,\ 1)$. بعد الانهيار: $(20,\ 4,\ 2,\ 1,\ 0.6,\ 0.4,\ 0.3,\ 0.2)$.

المطلوب: احسب $\|C\|_F$ والرتبة الفعّالة في الحالتين، وبيّن لماذا لا يكفي الناظم الفرونيوسي للكشف.

الحل:

١. قبل: $\|C\|_* = \operatorname{tr}(C) = 30.5$؛ $\|C\|_F^2 = 64+36+25+16+9+4+2.25+1 = 157.25 \Longrightarrow$ $\|C\|_F = 12.540$؛ $\operatorname{erank} = \dfrac{930.25}{157.25} = 5.916$.

٢. بعد: $\|C\|_* = 20+4+2+1+0.6+0.4+0.3+0.2 = 28.5$؛ $\|C\|_F^2 = 400+16+4+1+0.36+0.16+0.09+0.04 = 421.69 \Longrightarrow \|C\|_F = 20.535$؛ $\operatorname{erank} = \dfrac{812.25}{421.69} = 1.926$.

٣. المقارنة: $\|C\|_F$ **نما** من 12.54 إلى 20.54 (+64%)، في حين أن الرتبة الفعّالة **انهارت** من 5.92 إلى 1.93 (−67%).

النتيجة: مؤشّر الفرونيوسي يوحي «بنمو التمثيل» بينما الواقع أنه انهار على اتجاهين.

الربط بالذكاء الاصطناعي: هذا هو المبرّر الرياضي لِما تفعله VICReg و Barlow Twins: فهي تُضيف جزاءً على **التغاير** (يمنع تركّز الطيف) لا جزاءً على الناظم الكلي. الناظم الفرونيوسي يعاقب «الصغر» ولا يعاقب «التركّز»، أمّا الرتبة الفعّالة — وهي نسبة النووي إلى الفرونيوسي — فتقيس التركّز مباشرة. القاعدة التشخيصية: **راقب** erank **لا** $\|C\|_F$.

4.5.5 أخطاء شائعة في نواظم شاتن ومتراجحة فون نيومان

الخطأ الشائع	لماذا هو خطأ؟	التصحيح
الخلط بين $\|A\|_*$ (نووي) و $\|A\|_2$ (طيفي)	الأول مجموع القيم المفردة والثاني أكبرها	اكتب الرمز كاملاً ولا تكتفِ بالنجمة
افتراض $\|A\|_{S_p}$ يتناقص مع p كعائلة ℓ_p	الرتابة معكوسة ظاهرياً: $S_1 \geq S_2 \geq S_\infty$	تذكّر: S_∞ = أكبر قيمة مفردة = الأصغر
استخدام $\|A\|_F$ لقياس «الرتبة» أو التناثر الطيفي	فرونيوسي أعمى عن توزيع الطيف	استخدم النووي أو الرتبة الفعّالة
ظنّ أن فون نيومان تتطلّب تطابق القيم المفردة	التساوي يتطلّب تطابق **المحاور** (المتجهات المفردة)	افحص U, V لا Σ وحدها
تطبيق $\lvert\operatorname{tr}(A^\top B)\rvert \leq \|A\|_F\|B\|_F$ دائماً	صحيح لكنه قد يكون فضفاضاً بمعامل كبير عند انخفاض الرتبة	استخدم $\|A\|_2\|B\|_*$: لأحد الطرفين منخفض الرتبة
حساب $\|A\|_*$ بـ SVD لمصفوفة شبه موجبة	لا حاجة: $\|A\|_* = \operatorname{tr}(A)$ إذا كان $A \succeq 0$	تحقّق من شبه الموجبية أولاً
اعتبار $\|A\|_* \leq \|A\|_F$	الاتجاه معكوس: $\|A\|_* \geq \|A\|_F \geq \|A\|_2$	الصيغة الصحيحة: $\|A\|_* \leq \sqrt{r}\|A\|_F$
تجاهل أن الناظم النووي **غير قابل للاشتقاق** عند تكرار القيم المفردة	يسبّب مشكلات في خوارزميات التدرّج	استخدم دون التدرّج (subgradient) أو تنعيماً
س دون الجمعيّة $\|A+B\|_* \leq \|A\|_* + \|B\|_*$ مساواةً دائماً	صارمة عند تداخل الدعمين	تحقّق من تعامد المدى/مدى المنقول
الخلط بين «الرتبة» و«الرتبة الفعّالة»	الأولى صحيحة وغير متصلة؛ الثانية مستمرّة وحدٌّ أدنى	استخدم erank للتشخيص، والرتبة للقرارات البنيوية

الفكرة في سطر: في الأبعاد العالية، النواظم **لا تتقلّب**: طولُ متجه عشوائي، وناظمُ مصفوفة عشوائية، وطولُ إسقاطٍ عشوائي — كلّها تتركّز حول قيمتها المتوقَّعة بتركيزٍ أُسّي. هذه الظاهرة هي التي تجعل «البعد العالي» مكاناً صالحاً للعمل: المسافات محفوظة، والأخطاء العشوائية قابلة للضبط، والحدودُ الأسوأ-حالة (التي رأيناها في 3.5) متشائمة بمقدار جذري.

1.6.5 الصياغة الرسمية

نظرية (لمّة جونسون-ليندنشتراوس — JL).

ليكن $X \subseteq \mathbb{R}^d$ مجموعةً من n نقطة، وليكن $\varepsilon \in (0,1)$ و $\delta \in (0,1)$. لتكن $R \in \mathbb{R}^{k \times d}$ مصفوفة إسقاط عشوائي بمدخلات مستقلّة $R_{ij} \sim \mathcal{N}(0,\, 1/k)$. إذا كان

$$k \;\geq\; \frac{4\,\ln\!\left(n^2/\delta\right)}{\varepsilon^2 - \varepsilon^3} \qquad \Big(\text{وبصيغة مقاربة: } k = \mathcal{O}\!\left(\varepsilon^{-2}\log n\right)\Big) \tag{33.5}$$

فإنه باحتمال $\geq 1-\delta$ يتحقّق **لجميع الأزواج في وقت واحد**:

$$(1-\varepsilon)\,\|x-y\|_2^2 \;\leq\; \|Rx - Ry\|_2^2 \;\leq\; (1+\varepsilon)\,\|x-y\|_2^2, \qquad \forall\, x, y \in X$$

جدول رموز (33.5):

الرمز	المعنى	ملاحظات
X	مجموعة النقاط المراد إسقاطها	قد تكون تضمينات، أو عيّنات تدريب
$n = \lvert X\rvert$	عدد النقاط	عدد الأزواج $\binom{n}{2} \leq n^2/2$
d	البعد الأصلي	البعد المُراد تخفيضه
k	البعد بعد الإسقاط	الهدف: $k \ll d$
ε	التشويه المسموح (نسبةً إلى مربّع المسافة)	$\varepsilon = 0.1$ يعني $\pm 10\%$ في المربّع، أي $\approx \pm 5\%$ في المسافة
δ	احتمال الفشل المسموح	$\delta = 0.01$ يعني نجاحاً بـ 99%
R	مصفوفة الإسقاط العشوائي $k \times d$	X لا تعتمد على (oblivious): «عمياء»
$R_{ij} \sim \mathcal{N}(0, 1/k)$	توزيع المدخلات	التباين $1/k$ يجعل $\mathbb{E}\|Rx\|^2 = \|x\|^2$
$\ln$	اللوغاريتم الطبيعي	—
n^2 في اللوغاريتم	يأتي من اتحاد الاحتمالات على كل الأزواج	$\binom{n}{2} \leq n^2/2$
$(1 \pm \varepsilon)$ على **المربّع**	JL تحفظ **مربّعات** المسافات	للمسافات نفسها: $\sqrt{1 \pm \varepsilon}$
$\mathcal{O}(\varepsilon^{-2}\log n)$	الصيغة المقاربة الشهيرة	البعد المطلوب **لا يعتمد على** d **إطلاقاً**

نظرية (تركيز متجه واحد — χ^2).

لكل متجه ثابت $x \neq 0$:

$$\frac{k\,\|Rx\|_2^2}{\|x\|_2^2} \;\sim\; \chi^2_k, \qquad \mathbb{E}\|Rx\|_2^2 = \|x\|_2^2, \qquad \mathbb{P}\Big(\big|\,\|Rx\|_2^2 - \|x\|_2^2\,\big| \geq \varepsilon \|x\|_2^2\Big) \;\leq\; 2\exp\!\Big(-\tfrac{k(\varepsilon^2-\varepsilon^3)}{4}\Big) \tag{34.5}$$

جدول رموز (34.5):

الرمز	المعنى	ملاحظات
χ^2_k	توزيع مربع كاي بـ k درجة حرية	مجموع مربّعات k متغيّر قياسي
$\mathbb{E}\|Rx\|^2 = \|x\|^2$	الإسقاط **غير متحيّز** للطول	بفضل التباين $1/k$
$k\|Rx\|^2/\|x\|^2 \sim \chi^2_k$	التوزيع الدقيق	نسبة التركيز تحكمها χ^2
$2\exp(\cdot)$	الحدّ ذو الطرفين (أعلى وأسفل)	اتحاد احتمالَي الذيلين
$\varepsilon^2 - \varepsilon^3$	دالة التشويه في الأُسّ	أعظمُ قيمة لها على $(0,1)$ هي $\frac{4}{27}$ عند $\varepsilon = \frac{2}{3}$
$-k(\cdot)/4$	معدّل الاضمحلال الأُسّي	يتناسب مع k طرداً
الملاحظة الحاسمة	التركيز يعتمد على k **فقط**، لا على d	هذا هو سرّ قوّة JL

نظرية (تركيز ناظم المتجه الغاوسي).

ليكن $g \sim \mathcal{N}(0, I_d)$. الدالة $g \mapsto \|g\|_2$ هي 1-ليبشيتز، فبتركيز الغاوسي:

$$\mathbb{E}\|g\|_2^2 = d, \qquad \mathbb{E}\|g\|_2 \le \sqrt{d}, \qquad \mathbb{P}\Big(\big|\|g\|_2 - \mathbb{E}\|g\|_2\big| \ge t\Big) \;\le\; 2\,e^{-t^2/2} \tag{35.5}$$

جدول رموز (35.5):

الرمز	المعنى	ملاحظات
$g \sim \mathcal{N}(0, I_d)$	متجه غاوسي قياسي في $\mathbb{R}^d$	كل إحداثي $\mathcal{N}(0,1)$ مستقل
$\mathbb{E}\|g\|_2^2 = d$	مجموع التباينات	دقيق
$\mathbb{E}\|g\|_2 \le \sqrt{d}$	يتبع من Jensen (تربيع مقعّر)	والقيمة الفعلية $\sqrt{d}\,(1+\mathcal{O}(1/d))$
$\big\|\|g\| - \|h\|\big\| \le \|g-h\|_2$	1-ليبشيتز	من المتراجحة الفرقية
$2e^{-t^2/2}$	ذيل غاوسي	اضمحلال أُسّي في t^2
t	الانحراف المسموح	بالوحدات المطلقة (لا النسبية)
الانحراف النسبي	$\approx t/\sqrt{d}$	يتناقص مع البعد — «لعنة» تصبح «نعمة»

نظرية (ناظم المصفوفة العشوائية — غوردون / باي-ين).

ليكن $W \in \mathbb{R}^{m\times n}$ بمدخلات مستقلّة $\mathcal{N}(0, \sigma^2)$. عندئذٍ:

$$\mathbb{E}\|W\|_2 \;\le\; \sigma\big(\sqrt{m} + \sqrt{n}\big), \qquad \mathbb{P}\Big(\|W\|_2 \ge \mathbb{E}\|W\|_2 + t\Big) \;\le\; e^{-t^2/(2\sigma^2)}, \qquad \|W\|_F \approx \sigma\sqrt{mn} \tag{36.5}$$

جدول رموز (36.5):

الرمز	المعنى	ملاحظات
W	مصفوفة عشوائية $m \times n$	تهيئة أوزان، مصفوفة قياس عشوائية
σ^2	تباين المدخلات	في التهيئة: $\sigma^2 = 1/\text{fan_in}$ أو $2/\text{fan_in}$
$\sqrt{m} + \sqrt{n}$	النموذج النموذجي للناظم الطيفي	قانون غوردون
$\mathbb{E}\|W\|_2 \le \sigma(\sqrt{m}+\sqrt{n})$	الحدّ من فوق	محكَم مقارباً (باي-ين)
$e^{-t^2/(2\sigma^2)}$	تركيز أُسّي	لأن $\|W\|_2$ دالة σ-ليبشيتز في المدخلات
$\sqrt{mn}$	الناظم الفروبنيوسي النموذجي	أكبر من الطيفي بمعامل $\approx \frac{\sqrt{mn}}{\sqrt{m}+\sqrt{n}}$
$\frac{\sqrt{mn}}{\sqrt{m}+\sqrt{n}}$	معامل الفجوة	لمصفوفة مربّعة $n \times n$: $\frac{\sqrt{n}}{2}$ — ينمو مع العرض!

نتيجة (حفظ الضروب الداخلية). من JL بالاستقطاب (polarization):

$$\big|\langle Rx,\, Ry\rangle - \langle x,\, y\rangle\big| \;\le\; \frac{\varepsilon}{2}\big(\|x\|_2^2 + \|y\|_2^2\big) \;\xrightarrow[\|x\|=\|y\|=1]{}\; \le \varepsilon \tag{37.5}$$

نتيجة (تضمين الفضاءات الجزئية — subspace embedding). لإسقاط يحفظ **كل** المتجهات في فضاء جزئي بُعده d_0 (لا n نقطة منفصلة):

$$k \;=\; \mathcal{O}\!\left(\frac{d_0 + \ln(1/\delta)}{\varepsilon^2}\right) \quad\Longrightarrow\quad (1-\varepsilon)\|x\|^2 \le \|Rx\|^2 \le (1+\varepsilon)\|x\|^2,\ \forall x \in \mathcal{S} \tag{38.5}$$

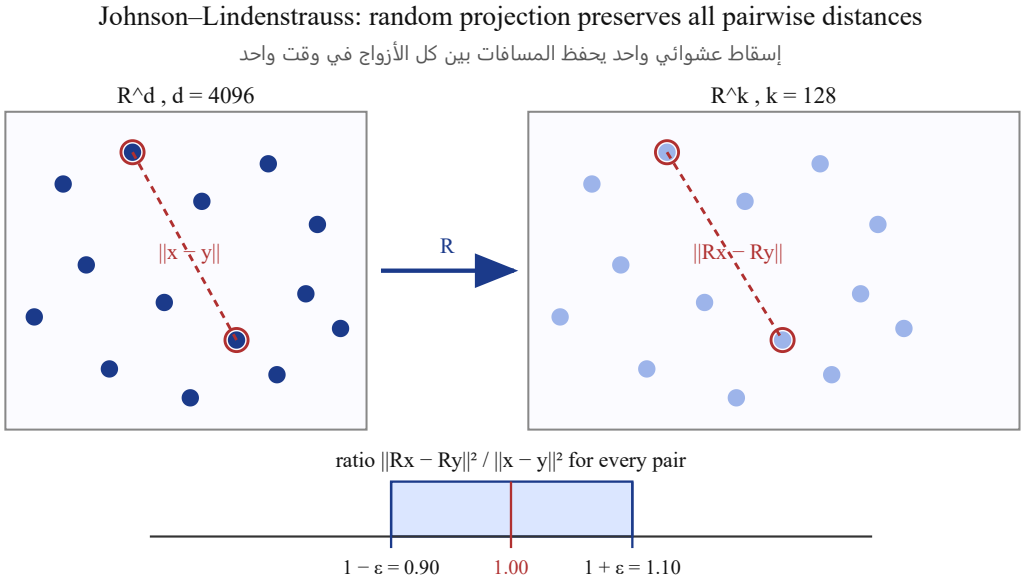
نتيجة (إحكام لمّة JL — الحدّ الأدنى). البعد $k = \mathcal{O}(\varepsilon^{-2}\log n)$ **مثاليّ** من حيث الاعتماد على ε و n:

$$k \;=\; \Omega\!\left(\varepsilon^{-2}\log n\right) \quad \text{ضروري} \tag{39.5}$$

جدول رموز (37.5)–(39.5):

الرمز	المعنى	ملاحظات
$\langle Rx, Ry\rangle$	الضرب الداخلي بعد الإسقاط	يحسب التشابه
$\langle x, y\rangle$	الضرب الداخلي الأصلي	—
$\frac{\varepsilon}{2}(\|x\|^2+\|y\|^2)$	حدّ الخطأ العام	—
$\le \varepsilon$ للمتجهات الوحدية	الحالة الشائعة في التضمينات المُطبَّعة	يبرّر البحث بالجداء الداخلي بعد الإسقاط
«الاستقطاب»	$\langle u, v\rangle = \frac{1}{4}(\|u+v\|^2 - \|u-v\|^2)$	المتطابقة التي تنقل JL من المسافات إلى الضروب
d_0	بُعد الفضاء الجزئي $\mathcal{S}$	أصغر بكثير من d في التطبيقات
$\mathcal{S}$	فضاء جزئي (subspace)	مثلاً فضاء الأعمدة الـ d_0 الأولى
(38.5) مقابل (33.5)	الأول يحفظ **مجموعةً غير منتهية**؛ والثاني n نقطة	(38.5) أقوى وأعمّ
$\Omega(\cdot)$	حدّ أدنى مقاربي	يعني «لا يمكن تحسين الاعتماد على ε, n»
النتيجة	البعد المطلوب $\asymp \varepsilon^{-2}\log n$	الاعتماد على d معدوم، والاعتماد على n لوغاريتمي

الشكل الهندسي: إسقاط عشوائي واحد يحفظ **كل** المسافات دفعةً واحدة:



شكل ٦.٥: *
لمّة جونسون–ليندنشتراوس: إسقاط عشوائي يحفظ المسافات

2.6.5 البرهان

برهان (34.5).

ليكن $x \neq 0$ ثابتاً. كل إحداثي من Rx هو $(Rx)_j = \sum_i R_{ji}x_i$ — تركيبة خطية لمتغيّرات غاوسية مستقلّة، فهو غاوسي بتباين $\sum_i \mathrm{Var}(R_{ji})x_i^2 = \frac{1}{k}\|x\|_2^2$. إذن:

$$\|Rx\|_2^2 \;=\; \frac{\|x\|_2^2}{k}\sum_{j=1}^{k} Z_j^2, \qquad Z_j \sim \mathcal{N}(0,1) \text{ مستقلّة}$$

أي أن $Y = \dfrac{k\|Rx\|^2}{\|x\|^2} \sim \chi^2_k$، و $\mathbb{E}\|Rx\|^2 = \frac{\|x\|^2}{k}\cdot k = \|x\|^2$ ✓. أما الذيول فبـ شيرنوف: لكل $0 < \varepsilon < 1$،

$$\mathbb{P}\big(Y \ge (1+\varepsilon)k\big) \le \big((1+\varepsilon)e^{-\varepsilon}\big)^{k/2} = \exp\Big(-\tfrac{k}{2}\big(\varepsilon - \ln(1+\varepsilon)\big)\Big) \;\le\; \exp\Big(-\tfrac{k}{2}\big(\tfrac{\varepsilon^2}{2} - \tfrac{\varepsilon^3}{3}\big)\Big)$$

حيث استخدمنا $\ln(1+\varepsilon) \le \varepsilon - \frac{\varepsilon^2}{2} + \frac{\varepsilon^3}{3}$. وبالمثل للذيل الأسفل $\mathbb{P}(Y \le (1-\varepsilon)k) \le \exp\big(-\frac{k\varepsilon^2}{4}\big)$. وباتحاد الاحتمالين والحطّ إلى الصيغة المتحفّظة $\frac{\varepsilon^2-\varepsilon^3}{4}$ نحصل على (34.5). ■

برهان (33.5).

نُطبّق (34.5) على متجه الفرق $z = x - y$ — وهو متجه ثابت لا يعتمد على R (لأن R عمياء). عدد الأزواج $\binom{n}{2} \le n^2/2$. باتحاد الاحتمالات:

$$\mathbb{P}(\text{فشل أيّ زوج}) \;\le\; \frac{n^2}{2}\cdot 2\exp\Big(-\tfrac{k(\varepsilon^2-\varepsilon^3)}{4}\Big) = n^2\exp\Big(-\tfrac{k(\varepsilon^2-\varepsilon^3)}{4}\Big)$$

وبجعل هذا $\le \delta$ نحصل على $k \ge \dfrac{4\ln(n^2/\delta)}{\varepsilon^2-\varepsilon^3}$. ■

برهان (35.5).

الدالة $f(g) = \|g\|_2$ تحقّق $|f(g)-f(h)| \le \|g-h\|_2$ (المتراجحة الفرقية)، فهي 1-ليبشيتز. وبتركيز قياس الغاوس (Gaussian functions): Lipschitz for concentration $\mathbb{P}(|f(g)-\mathbb{E}f| \ge t) \le 2e^{-t^2/2}$. أمّا $\mathbb{E}\|g\|^2 = \sum_i \mathbb{E}g_i^2 = d$، و $\mathbb{E}\|g\| \le \sqrt{\mathbb{E}\|g\|^2} = \sqrt{d}$ بتطبيق Jensen على الدالة المقعّرة $\sqrt{\cdot}$. ■

برهان (36.5).

نكتب $W = \sigma G$ بـ G ذي مدخلات $\mathcal{N}(0,1)$. الدالة $G \mapsto \|G\|_2$ هي 1-ليبشيتز بالناظم الفرونيوسي على $\mathbb{R}^{m\times n}$ (لأن $\big|\|G\|_2 - \|H\|_2\big| \le \|G-H\|_2 \le \|G-H\|_F$)؛ فبتركيز الغاوس في بُعد mn: $\mathbb{P}(\|G\|_2 \ge \mathbb{E}\|G\|_2 + s) \le e^{-s^2/2}$. وبالتحجيم $t = \sigma s$ نحصل على الحدّ الثاني. أمّا الحدّ الأول $\mathbb{E}\|W\|_2 \le \sigma(\sqrt{m}+\sqrt{n})$ فهو **لامتساوية غوردون** (Gordon) للعمليات الغاوسية، ونكتفي بالإحالة إليها؛ ونظرية باي-ين (Bai–Yin) تكملها بأن النسبة $\to 1$ مقاربياً. ■

برهان (37.5).

بالاستقطاب:

$$\langle Rx, Ry\rangle - \langle x, y\rangle = \tfrac{1}{4}\Big[\big(\|R(x+y)\|^2 - \|x+y\|^2\big) - \big(\|R(x-y)\|^2 - \|x-y\|^2\big)\Big]$$

وبتطبيق JL على المتجهين $x+y$ و $x-y$ ثم متراجحة المثلث:

$$\big|\langle Rx,Ry\rangle-\langle x,y\rangle\big| \le \tfrac{1}{4}\Big[\varepsilon\|x+y\|^2+\varepsilon\|x-y\|^2\Big] = \tfrac{\varepsilon}{4}\big(2\|x\|^2+2\|y\|^2\big) = \tfrac{\varepsilon}{2}\big(\|x\|^2+\|y\|^2\big) \qquad \blacksquare$$

تنبيه تفسيري: JL تحفظ **مربّعات** المسافات ضمن $(1\pm\varepsilon)$؛ فالمسافات نفسها محفوظة ضمن $\sqrt{1+\varepsilon} \le 1+\tfrac{\varepsilon}{2}$ و $\sqrt{1-\varepsilon} \ge 1-\tfrac{\varepsilon}{2}$ — أي ضمن $(1\pm\tfrac{\varepsilon}{2})$ تقريباً. كثير من الأخطاء في الأدبيات التطبيقية يأتي من الخلط بين النسبتين.

3.6.5 خمسة عشر مثالاً محلولاً من الواقع

مثال (6.5-1): كم بُعداً يلزم لإسقاط مليون تضمين بتشويه 10%؟

المعطيات: $n=10^6$ نقطة في $\mathbb{R}^d$، و $\varepsilon=0.1$، و $\delta=0.01$.
المطلوب: البعد k المطلوب بصيغة (33.5)، ومقارنته بقاعدة «$8\ln n/\varepsilon^2$».
الحل:

١. $\varepsilon^2-\varepsilon^3 = 0.01-0.001 = 0.009$.

٢. $\ln(n^2/\delta) = \ln(10^{12}/0.01) = \ln(10^{14}) = 14\ln 10 = 32.2362$.

٣. $k = 14328 \implies k \ge \dfrac{4\times 32.2362}{0.009} = \dfrac{128.945}{0.009} = 14327.2$.

٤. قاعدة الإبهام: $\dfrac{8\ln n}{\varepsilon^2} = \dfrac{8\times 13.8155}{0.01} = 11052$.

٥. الفرق بينهما معامل 1.30 — أي أن الصيغة المتحفّظة والقاعدة المقاربة متوافقتان في المرتبة.

النتيجة: $k \approx 1.43\times 10^4$ يكفي لحفظ كل مسافات مليون نقطة ضمن $\pm 10\%$ في المربّع ($\approx \pm 5\%$ في المسافة).
الربط بالذكاء الاصطناعي: لاحظ أن k **لا يعتمد على** d **إطلاقاً** — فإسقاط تضمينات من $d = 12288$ (نموذج لغوي ضخم) إلى $k \approx 14000$ لا يحقّق شيئاً! هذه هي النقطة التي يخطئ فيها كثيرون: JL مفيدة فقط عندما يكون $d \gg \varepsilon^{-2}\log n$. سنفحص ذلك صراحةً في المثال (6.5-6).

مثال (6.5-2): متجه واحد مقابل مليون زوج — أثر معامل $\log n$

المعطيات: $\varepsilon=0.1$، احتمال فشل مطلوب 1%.
المطلوب: k اللازم **لمتجه واحد**، ثم لمليون نقطة، ونسبة الزيادة.
الحل:

١. **متجه واحد:** $2\exp\!\big(-\tfrac{k(\varepsilon^2-\varepsilon^3)}{4}\big) \le 0.01 \implies \exp\!\big(-\tfrac{0.009k}{4}\big) \le 0.005 \implies 0.00225\,k \ge \ln 200 = 5.2983$
$\implies k \ge 2354.8 \implies k = 2355$.

٢. مليون نقطة (من 5.6-1): $k = 14328$.

٣. النسبة: $14328/2355 = 6.08$.

٤. التفسير النظري: k لمتجه واحد $\propto \ln(2/\delta)$؛ ولـ n نقطة $\propto \ln(n^2/\delta) = 2\ln n + \ln(1/\delta)$. الفرق هو $2\ln n = 2 \times 13.8155 = 27.63$ بُعداً إضافياً ✓ في اللوغاريتم — أي $4 \times 27.63/0.009 = 12280$ متوافق مع الفرق 11973.

النتيجة: حفظ **متجه واحد** يحتاج $k \approx 2355$، وحفظ **كل الأزواج** لمليون نقطة يحتاج $k \approx 14328$ — أي 6.1 أضعاف.

الربط بالذكاء الاصطناعي: هذا الفرق هو ثمن «الضمان الشامل». في التطبيقات التي تريد ضماناً على متجه واحد (مثل تقدير ناظم التدرّج للمراقبة، أو تقدير طول تضمين واحد)، يكفي k أصغر بـ 6 مرات من الضمان الشامل على كل الأزواج. اختيار نوع الضمان يحدّد التكلفة — ولا يجوز الخلط بينهما.

مثال (5.6-3): ناظم المتجه الغاوسي في بُعد 4096 — كم هو متوقَّع؟

المعطيات: $g \sim \mathcal{N}(0, I_{4096})$.
المطلوب: القيمة المتوقَّعة لناظمه، واحتمال أن ينحرف بأكثر من 5 أو 15.
الحل:

١. $\mathbb{E}\|g\|_2^2 = d = 4096 \Longrightarrow \sqrt{4096} = 64$.

٢. $\mathbb{E}\|g\|_2 \le 64$ (والقيمة الفعلية أدنى قليلاً: $63.992 = 64 - \frac{1}{2\times 64}$).

٣. من (5.6-35): $\mathbb{P}\big(\big|\|g\|_2 - \mathbb{E}\|g\|_2\big| \ge t\big) \le 2e^{-t^2/2}$.

٤. عند $t = 5$: $2e^{-12.5} = 2 \times 3.727 \times 10^{-6} = 7.45 \times 10^{-6}$.

٥. عند $t = 15$: $2e^{-112.5} \approx 2 \times 5.6 \times 10^{-49}$ — صفر عملياً.

٦. الانحراف **النسبي** المعتاد: $t/\sqrt{d} = 5/64 = 7.8\%$ عند $t = 5$ وهو احتماله $< 10^{-5}$.

النتيجة: $\|g\|_2 = 64$ بحسم؛ فاحتمالُ انحرافٍ مقداره 5 (أي 7.8%) أقلّ من 10^{-5}.

الربط بالذكاء الاصطناعي: في الأبعاد العالية «كل المتجهات العشوائية طولها متساوٍ». هذه حقيقة مضادّة للحدس لكنها حاسمة: في فضاء تضمين بُعد 4096، متجهان عشوائيان **متعامدان تقريباً** وطولاهما متماثلان. ولهذا تعمل تهيئة الأوزان الغاوسية بثبات، ولهذا يفشل مقياس «المسافة الإقليدية الخام» أحياناً في التمييز بين تضمينات عشوائية ومتعلَّمة — فالطول وحده لا يحمل معلومة في البعد العالي.

مثال (5.6-4): الناظم الطيفي مقابل الفروبنيوسي لمصفوفة أوزان مُهيَّأة عشوائياً

المعطيات: $W \in \mathbb{R}^{1024\times 768}$ بمدخلات $\mathcal{N}(0, \sigma^2)$ و $\sigma = 0.05$.

المطلوب: قارن $\mathbb{E}\|W\|_2$ بـ $\|W\|_F$ النموذجي، ومدى تركيز كلٍّ منهما.
الحل:

١. $\sqrt{m}+\sqrt{n}=\sqrt{1024}+\sqrt{768}=32+27.7128=59.7128$.

٢. $\mathbb{E}\|W\|_2 \le \sigma(\sqrt{m}+\sqrt{n})=0.05\times 59.7128=2.9856$.

٣. $\|W\|_F \approx \sigma\sqrt{mn}=0.05\sqrt{786432}=0.05\times 886.81=44.34$.

٤. معامل الفجوة: $\dfrac{\sqrt{mn}}{\sqrt{m}+\sqrt{n}}=\dfrac{886.81}{59.71}=14.85=\dfrac{44.34}{2.9856}$ ✓.

٥. التركيز: $\mathbb{P}(\|W\|_2 \ge 2.9856+t)\le e^{-t^2/(2\sigma^2)}$. عند $t=0.3$: $e^{-0.09/0.005}=e^{-18}=1.5\times10^{-8}$.

النتيجة: الناظم الطيفي $\|W\|_2 \approx 3.0$ بتركيز شديد، مقابل فرونيوسي $\|W\|_F \approx 44.3$ — فجوة بمعامل 14.9.

الربط بالذكاء الاصطناعي: هذه الفجوة هي سبب الالتباس الأكثر شيوعاً في بحوث التهيئة: تبدو $\|W\|_F = 44$ «كبيرة» لكن ثابت ليبشيتز الفعلي للطبقة هو 3. ولأن الفجوة تنمو مع العرض ($\sqrt{n}/2$ للمصفوفات المربّعة)، فإن أي تحليل يستخدم $\|W\|_F$ يزداد تشاؤماً كلما كبرت الشبكة — في حين أن السلوك الفعلي (الطيفي) ثابت. القاعدة: **حلّل بالطيفي، وحوِّل فقط عند الضرورة.**

مثال (5-6.5): اختيار تباين التهيئة بحيث يكون $\|W\|_2 = 1$

المعطيات: طبقة $m \times n$ بـ $m=n=1024$. خياران: تهيئة «He» ($\sigma=\sqrt{2/\text{fan_in}}=\sqrt{2/1024}$) وتهيئة «طيفية الوحدة».
المطلوب: الناظم الطيفي الناتج في كل خيار، وقيمة σ التي تجعل $\mathbb{E}\|W\|_2 \approx 1$.
الحل:

١. تهيئة He: $\sigma=\sqrt{2/1024}=\sqrt{0.001953}=0.044194$؛ و $\mathbb{E}\|W\|_2 \le 0.044194\times(32+32)=0.044194\times 64=2.828$.

٢. الشرط $\sigma(\sqrt{m}+\sqrt{n})=1$ يعطي $\sigma=\dfrac{1}{64}=0.015625$.

٣. نسبة التصغير المطلوبة: $0.044194/0.015625=2.828$ — أي أن تهيئة He تعطي ناظماً طيفياً ≈ 2.83 لكل طبقة.

٤. أثر التراكم على $L=12$ طبقة: $2.83^{12}=e^{12\times 1.0403}=e^{12.484}=2.64\times10^5$ (حدّ أعلى للناظم الطيفي الكلي) مقابل $1^{12}=1$ بالتهيئة الطيفية.

النتيجة: لضمان $\|W\|_2=1$ عند التهيئة استخدم $\sigma=1/(\sqrt{m}+\sqrt{n})$؛ وهو أصغر من تهيئة He بمعامل ≈ 2.8.
الربط بالذكاء الاصطناعي: هذا هو المبرّر الكمّي لتقنيات مثل «تهيئة دلتا الطيفية» و **orthogonal init** و **Fixup**: فهي تختار التباين (أو البنية) بحيث يكون الناظم الطيفي لكل طبقة ≈ 1، فلا ينفجر ناظم الشبكة الكلي أُسّياً مع العمق. الفرق بين 2.83^{12} و 1^{12} هو الفرق بين شبكة قابلة للتدريب وشبكة تحتاج تطبيعاً في كل طبقة.

مثال (6-6.5): JL لا تنفع دائماً — متى يكون $k > d$؟

المعطيات: تضمينات بـ $d = 768$، و $n = 10^6$ نقطة، و $\varepsilon = 0.1$، و $\delta = 0.1$.
المطلوب: هل يُجدي الإسقاط العشوائي تخفيضاً هنا؟
الحل:

١. $4\ln(n^2/\delta) = 4\ln(10^{12}/0.1) = 4\ln(10^{13}) = 4 \times 29.9336 = 119.734$.

٢. $k \geq \dfrac{119.734}{0.009} = 13304$.

٣. لكن $k = 13304 > d = 768$ — أي أن «البعد المخفَّض» المطلوب **أكبر من البعد الأصلي** بـ 17.3 مرة.

٤. السبب البنيوي: أعظمُ قيمة ممكنة لـ $\varepsilon^2 - \varepsilon^3$ على $(0,1)$ هي $\frac{4}{27} = 0.1481$ (عند $\varepsilon = \frac{2}{3}$)؛ فأصغرُ k يمكن أن يضمنه أيّ $\varepsilon \in (0,1)$ هو $k_{\min} = \dfrac{119.734}{0.1481} = 808$ — وهو **أيضاً** أكبر من 768.

٥. إذن: لا توجد قيمة $\varepsilon \in (0,1)$ يستطيع الإسقاط العشوائي ضمانها لهذه البيانات ببعدٍ أصغر من 768.

النتيجة: لـ $d = 768$ و $n = 10^6$، **لا يحقّق JL أي تخفيض مضمون.** تعمل JL فقط حين $d \gtrsim \varepsilon^{-2}\log n$ (هنا: $\varepsilon^{-2}\log n = 100 \times 13.8 = 1380 > 768$).

الربط بالذكاء الاصطناعي: نتيجةٌ مهمّة وكثيراً ما تُتجاهل: تقنيات «تخفيض البعد العشوائي» (المبنية على JL) تفيد في المسائل العلمية ذات d الضخم و n المعتدل (مثل إشارات الاستشعار، والجينوم، والرسوم البيانية الضخمة)، أمّا في التضمينات الدلالية حيث $d \approx 10^3$ و $n \approx 10^6$ فهي **لا تفيد.** لهذا تعتمد محرّكات ANN على التكميم و LSH و HNSW — وهي تقنيات تُضعف الضمان من «كل الأزواج» إلى «أقرب الجيران غالباً» — لا على JL.

مثال (7-6.5): اعتماد k على n لوغاريتمي — جدول

المعطيات: $\varepsilon = 0.1$، $\delta = 0.05$، و $n \in \{10^3, 10^4, 10^5, 10^6\}$.
المطلوب: البعد k المطلوب في كل حالة.
الحل:

١. الصيغة: $k = \dfrac{4\big(2\ln n + \ln(1/0.05)\big)}{0.009} = \dfrac{4(2\ln n + 2.9957)}{0.009}$.

٢. $n = 10^3$: $2\ln n = 13.8155 \Rightarrow k = \dfrac{4 \times 16.8112}{0.009} = 7472$.

٣. $n = 10^4$: $2\ln n = 18.4207 \Rightarrow k = \dfrac{4 \times 21.4164}{0.009} = 9518$.

٤. $n = 10^5$: $2\ln n = 23.0259 \Rightarrow k = \dfrac{4 \times 26.0216}{0.009} = 11565$.

٥. $n = 10^6$: $2\ln n = 27.6310 \Rightarrow k = \dfrac{4 \times 30.6267}{0.009} = 13612$.

٦. الزيادة من 10^3 إلى 10^6 (مضاعفة العدد ألف مرة): $13612/7472 = 1.82$ فقط.

النتيجة: مضاعفة عدد النقاط ألف مرة تزيد البعد المطلوب بـ 82% فقط — نموٌّ لوغاريتمي.

الربط بالذكاء الاصطناعي: هذا هو سبب قابليّة الأساليب العشوائية للتوسّع: تكلفة الضمان تنمو **لوغاريتمياً** مع حجم البيانات، لا خطّياً. ولهذا تُستخدم التخفيضات العشوائية في تعلّم الآلة على نطاق واسع (Randomized SVD، sketching للانحدار، random features) — فحجم البيانات لا يُلزم برفع البعد إلّا قليلاً.

مثال (5.6-8): القناع العشوائي (Dropout/Masking) — متى يحفظ الناظم؟

المعطيات: متجه $x \in \mathbb{R}^d$ بـ $d = 4096$، وقناع عشوائي M بمدخلات برنولية $\mathbb{P}(m_i = 1) = p = 0.9$.

المطلوب: الانحراف النسبي المعياري لـ $\|Mx\|^2$ لحالتين: متجه «مستوٍ» ومتجه «قِمّي» (شبه أحادي).

الحل:

١. $\mathbb{E}\|Mx\|^2 = p\|x\|^2 \implies \|Mx\|^2 = \sum_i m_i x_i^2$؛ والتطبيع بـ $1/p$ يجعله غير متحيّز.

٢. التباين: $\mathrm{Var}(\|Mx\|^2) = p(1-p)\sum_i x_i^4 \le p(1-p)\|x\|_\infty^2\|x\|_2^2$.

٣. الانحراف المعياري النسبي: $\dfrac{\sqrt{\mathrm{Var}}}{p\|x\|^2} \le \sqrt{\dfrac{1-p}{p}} \cdot \dfrac{\|x\|_\infty}{\|x\|_2}$.

٤. **الحالة المستوية** ($x_i = 1$ للكل): $\dfrac{\|x\|_\infty}{\|x\|_2} = \dfrac{1}{64} \implies$ الانحراف $= 0.3333 \times 0.015625 \le \sqrt{\frac{0.1}{0.9}} \times \frac{1}{64} = 0.00521$ (أي 0.52%).

٥. **الحالة القِمّية** ($x = e_1$ أحادي): $\dfrac{\|x\|_\infty}{\|x\|_2} = 1 \implies$ الانحراف 0.3333 $\le$ (أي 33%) — وبالفعل: فالإحداثي الوحيد يُحذف باحتمال 10%!

النتيجة: القناع يحفظ الناظم بدقة 0.5% للمتجهات المستوية، ويفشل بنسبة 33% للمتجهات القِمّية.

الربط بالذكاء الاصطناعي: هذا يفسّر قاعدة عملية معروفة: **القناع العشوائي (dropout) آمن على التمثيلات الكثيفة، ومدمّر على المدخلات المتناثرة** (مثل أكياس الكلمات أو الترميز الأحادي) — ولهذا تُستخدم معدّلات إسقاط مختلفة أو تُستثنى طبقة التضمين من القناع. الصيغة $\sqrt{(1-p)/p} \cdot \|x\|_\infty/\|x\|_2$ تعطي المعيار الدقيق: «مدى تركّز» المتجه هو ما يحدّد الخطورة، لا بُعده.

مثال (5.6-9): تقدير الميزات العشوائية (Random Features) — كم ميزة نحتاج؟

المعطيات: تقريب نواة بميزات عشوائية، نريد خطأً نسبياً $\varepsilon = 0.1$ على **زوج واحد** باحتمال فشل $\delta = 0.05$؛ ثم على كل أزواج $n = 5000$ نقطة.

المطلوب: عدد الميزات D في الحالتين.

الحل:

١. زوج واحد: $2\exp\!\left(-\frac{D(\varepsilon^2-\varepsilon^3)}{4}\right) \le 0.05 \Longrightarrow \exp\!\left(-\frac{0.009D}{4}\right) \le 0.025 \Longrightarrow 0.00225\,D \ge \ln 40 = 3.6889 \Longrightarrow D \ge 1640$.

٢. كل الأزواج ($n = 5000$، $\binom{n}{2} \le 1.25 \times 10^7$): $D \ge \frac{4\ln(n^2/\delta)}{0.009} = \frac{4\ln(2.5\times 10^7/0.05)}{0.009} = \frac{4\ln(5\times 10^8)}{0.009} = \frac{4 \times 20.030}{0.009} = 8902$.

٣. النسبة: $8902/1640 = 5.43$ — ثمن الضمان الشامل.

النتيجة: $D \approx 1640$ لزوج واحد، و $D \approx 8900$ لكل أزواج 5000 نقطة.

الربط بالذكاء الاصطناعي: طريقة الميزات العشوائية (Rahimi–Recht) تحوّل نواةً غير قابلة للتوسّع إلى جداء داخلي في بُعد D — فتصير تكلفة التدريب خطّية في عدد العيّنات. عدد الميزات المطلوب يتبع قانون JL نفسه: $\mathcal{O}(\varepsilon^{-2}\log n)$. ولهذا تعمل «محوّلات الطيف العشوائي» (Performers/RFA) بآلاف الميزات لا بملايين.

مثال (5.6-10): حفظ الضروب الداخلية — هل يبقى البحث بالتشابه صالحاً بعد الإسقاط؟

المعطيات: تضمينات مُطبَّعة ($\|\hat{x}\|_2 = \|\hat{y}\|_2 = 1$)؛ إسقاط JL بـ $\varepsilon = 0.1$.
المطلوب: حدّ الخطأ في التشابه بعد الإسقاط.
الحل:

١. من (5.37) مع $\|x\| = \|y\| = 1$: $\left|\langle R\hat{x},\, R\hat{y}\rangle - \langle \hat{x}, \hat{y}\rangle\right| \le \varepsilon = 0.1$.

٢. مثال: لو كان $\langle \hat{x}, \hat{y}\rangle = 0.80$ فإن $\langle R\hat{x}, R\hat{y}\rangle \in [0.70,\, 0.90]$.

٣. تحويل إلى زاوية: $\arccos(0.70) = 45.6°$ و $\arccos(0.90) = 25.8°$ — أي أن الزاوية المدركة تتراوح بين $25.8°$ و $45.6°$ بدلاً من $\arccos(0.8) = 36.9°$.

٤. تحويل إلى مسافة: من المثال (5.2-7)، $\|\hat{x} - \hat{y}\|_2 = \sqrt{2(1-\cos\theta)}$، فالمسافة الأصلية $\sqrt{0.4} = 0.632$ وبعد الإسقاط في المدى $[\sqrt{0.2},\, \sqrt{0.6}] = [0.447,\, 0.775]$.

النتيجة: التشابه بعد الإسقاط دقيق ضمن ± 0.1 (مطلقاً)، والترتيب محفوظ تقريباً لكن ليس تماماً.

الربط بالذكاء الاصطناعي: هذا يحدّد متى يجوز «الضغط قبل البحث»: إذا كانت الفجوة بين النتيجة الصحيحة والمنافِسة أصغر من ε، فالإسقاط قد يقلب الترتيب. القاعدة العملية: **يجب أن يكون هامش الثقة في الاسترجاع أكبر من** ε، وإلا فالإسقاط يدمّر الدقة. ولهذا تُستخدم الإسقاطات العشوائية للمطابقة التقريبية مع إعادة ترتيب (re-ranking) بالمتجهات الأصلية على المرشّحين الأوائل.

مثال (5.6-11): «الثبات مع العرض» — لماذا ناظم الطبقة الغاوسية لا يعتمد على d؟

المعطيات: طبقة مربّعة $d \times d$ بمدخلات $\mathcal{N}(0,\, 1/d)$ (تهيئة شائعة: التباين $= 1/\text{fan_in}$).
المطلوب: $\mathbb{E}\|W\|_2$ كدالّة في d.
الحل:

١. $\sigma = 1/\sqrt{d}$.

٢. $\mathbb{E}\|W\|_2 \le \sigma(\sqrt{d}+\sqrt{d}) = \dfrac{2\sqrt{d}}{\sqrt{d}} = 2$.

٣. التحقّق عند $d = 512$: $\sigma = 1/\sqrt{512} = 0.044194$؛ و $0.044194 \times (22.627 + 22.627) = 0.044194 \times 45.255 = 2.0$ ✓.

٤. التحقّق عند $d = 4096$: $\sigma = 1/64 = 0.015625$؛ و $0.015625 \times (64+64) = 2.0$ ✓.

٥. أمّا $\|W\|_F \approx \sigma\sqrt{d^2} = \sigma d = \sqrt{d}$ — **ينمو مع** d (64 عند $d = 4096$).

النتيجة: الناظم الطيفي 2 **مستقل عن** d؛ والفرونيوسي $\sqrt{d}$ ينمو معه.

الربط بالذكاء الاصطناعي: هذه هي المتطابقة التي تجعل التهيئة القياسية «صالحة لكل عرض»: اختيار $\sigma^2 = 1/\text{fan_in}$ يجعل الناظم الطيفي — أي ثابت ليبشيتز — ثابتاً لا يتغيّر بتوسيع الشبكة. أمّا لو ثبّتنا σ فسيكون الناظم الطيفي $\propto \sqrt{d}$ وتنفجر الشبكة مع العرض. كل مخطّطات التهيئة الحديثة (He، Glorot، Fixup، μP) هي في جوهرها اختيارات لـ σ تجعل كمية طيفية معيّنة ثابتة مع العرض.

مثال (12-6.5): Sketching للانحدار الخطي — من مليون صف إلى كم؟

المعطيات: $A \in \mathbb{R}^{N\times d}$ بـ $N = 10^6$ صف و $d = 100$ عمود؛ نريد حلّ المربّعات الصغرى بتخفيض عدد الصفوف بـ $S \in \mathbb{R}^{k\times N}$ غاوسي، بـ $\varepsilon = 0.1$ و $\delta = 0.01$.

المطلوب: عدد الصفوف بعد التخفيض k، ونسبة التسريع.

الحل:

١. من (38.5): $k = \mathcal{O}\big((d + \ln(1/\delta))/\varepsilon^2\big)$. بالثابت 4: $k = \dfrac{4(100+\ln 100)}{0.01}$.
$\dfrac{4(100+4.6052)}{0.01} = \dfrac{417.42}{0.01} = 41742$.

٢. نسبة التخفيض: $10^6/41742 = 23.96 \Longrightarrow$ تسريع ≈ 24 مرة في تشكيل النظام المُخفَّض.

٣. لاحظ أن k يعتمد على $d = 100$ و $\log(1/\delta)$ **لا على** $N = 10^6$: فالتخفيض يتحسّن (نسبةً) كلما كبر N.

٤. الضمان: لكل z في فضاء أعمدة A (بُعده $\le d+1$): $(1-\varepsilon)\|z\|^2 \le \|Sz\|^2 \le (1+\varepsilon)\|z\|^2 \Longrightarrow$ حلّ المسألة المُخفَّضة قريبٌ من حلّ المسألة الأصلية بعامل $(1+\varepsilon)/(1-\varepsilon) = 1.222$.

النتيجة: $k \approx 4.2\times 10^4$ صف تكفي لحلّ مسألة من 10^6 صف و 100 عمود بخطأ نسبي $\approx 22\%$.

الربط بالذكاء الاصطناعي: هذا هو أساس «المربّعات الصغرى المُخفَّفة» (sketched least squares) و randomized SVD في تعلّم الآلة واسع النطاق: حين يكون $N \gg d$، لا يحتاج الحل إلا إلى $\mathcal{O}(d/\varepsilon^2)$ صفوف — فتُنجز المسألة بتكلفة لا تكاد تعتمد على حجم البيانات. الفكرة نفسها خلف «تخفيض بيانات التدريب» (coresets) وضغط مجموعات البيانات الضخمة.

مثال (13-6.5): تقدير ناظم التدرّج في نموذج ضخم — التخفيض للمراقبة

المعطيات: تدرّج $g \in \mathbb{R}^{10^8}$؛ نريد تقدير $\|g\|_2$ بخطأ نسبي $\varepsilon = 0.05$ باحتمال نجاح 99%.
المطلوب: عدد الإحداثيات المُخفَّفة k، ونسبة الضغط.
الحل:

١. متجه واحد (ليس كل الأزواج): $2\exp\!\left(-\frac{k(\varepsilon^2-\varepsilon^3)}{4}\right) \le 0.01$.

٢. $\varepsilon^2 - \varepsilon^3 = 0.0025 - 0.000125 = 0.002375$.

٣. $\exp\!\left(-\frac{0.002375\,k}{4}\right) \le 0.005 \implies 0.00059375\,k \ge 5.2983 \implies k \ge 8922 \implies k = 8922$.

٤. نسبة الضغط: $10^8 / 8922 = 11208$ مرة.

٥. تحذير: هذا يحفظ **الناظم** فقط، لا المتجه نفسه — فلا يمكن استعادة g من الإسقاط.

النتيجة: $k \approx 8900$ إحداثياً تكفي لتقدير ناظم تدرّج بـ 10^8 إحداثي ضمن 5% — ضغط بأكثر من أربعة مراتب.
الربط بالذكاء الاصطناعي: تخفيض الناظم (norm sketching) مفيد للمراقبة: تتبّع $\|g\|_2$ لأجل التكيّف مع معدّل التعلّم أو الكشف عن انفجار التدرّج، بتكلفة اتصال لا تُذكر في التدريب الموزّع. أمّا **التحديث نفسه** فلا يمكن تخفيضه بهذه الطريقة — فاستعادة الاتجاه تتطلّب $k \ge d$. التمييز بين «قياس كمية قياسية» و«استعادة متجه» هو التمييز الحاسم في تصميم أنظمة الضغط.

مثال (14-6.5): إحكام JL — هل يمكن تحسين $\varepsilon^{-2}\log n$؟

المعطيات: $n = 10^6$، $\varepsilon = 0.1$. الحدّ الأعلى من (33.5) أعطى $k = 13612$ (مع $\delta = 0.05$). الحدّ الأدنى النظري $k = \Omega(\varepsilon^{-2}\log n)$.
المطلوب: قدّر حجم الفجوة بين الحدّين واستنتج.
الحل:

١. الحدّ الأدنى المقاربي: $k_{\text{lower}} \asymp \frac{\log n}{\varepsilon^2} = \frac{13.8155}{0.01} = 1381.6$ (بثابت 1).

٢. الحدّ الأعلى المحسوب: $k_{\text{upper}} = 13612$.

٣. النسبة: $13612 / 1381.6 = 9.85$ — أي أقلّ من مرتبة واحدة.

٤. الاستنتاج: الاعتماد على ε^{-2} و $\log n$ **مثالي**؛ والفجوة المتبقية ثابتٌ عددّي (بين 1 و 10 تقريباً) يمكن تحسينه بتحليل أدقّ أو بمصفوفات إسقاط مُهيَّكلة (مثل تحويلات هادامار السريعة المقعّبة).

٥. لكن لا يمكن تحسين الاعتماد على ε: فالانتقال من $\varepsilon = 0.1$ إلى $\varepsilon = 0.05$ يضاعف k أربع مرات في الحدّين معاً.

النتيجة: صيغة $k \asymp \varepsilon^{-2} \log n$ مثالية من حيث الاعتماد الوظيفي؛ وتحسينها ممكن في الثابت فقط.

الربط بالذكاء الاصطناعي: معرفة أن الحدّ مثاليّ تُوجّه الجهد الهندسي بشكل صحيح: لا جدوى من البحث عن إسقاط «أفضل جوهرياً»؛ الجهد المفيد يذهب إلى (أ) تحسين الثابت، (ب) استخدام إسقاطات مُهيَّكلة (Fast JL: هادامار + قناع متناثر) تخفض **التكلفة الحسابية** من $\mathcal{O}(kd)$ إلى $\mathcal{O}(d \log d)$، و (ج) إضعاف الضمان إلى «أقرب الجيران» كما في LSH.

مثال (5.6-15): تكميم عشوائي مقابل حدّ أسوأ حالة — الفجوة بمعامل ≈ 20

المعطيات: مصفوفة $W \in \mathbb{R}^{512 \times 512}$، خطوة تكميم $\Delta = 2^{-7} = 0.0078125$ (راجع المثال 5.3-13).

المطلوب: قارن حدّ أسوأ حالة (الناتج من التكافؤ) بالقيمة النموذجية (الناتجة من تركيز ناظم المصفوفة العشوائية).

الحل:

١. خطأ الإحداثي: منتظم على $[-\Delta/2, \Delta/2]$، بانحراف معياري $\sigma_e = \dfrac{\Delta}{2\sqrt{3}} = \dfrac{0.0078125}{3.4641} = 0.0022555$.

٢. حدّ أسوأ حالة (من 5.3-13): $\|\Delta W\|_2 \le \|\Delta W\|_F \le \sqrt{mn}\,\frac{\Delta}{2} = 512 \times 0.00390625 = 2.0$.

٣. القيمة النموذجية بـ (5.6-3): $\mathbb{E}\|\Delta W\|_2 \approx \sigma_e(\sqrt{m} + \sqrt{n}) = 0.0022555 \times (22.627 + 22.627) = 0.0022555 \times 45.255 = 0.1021$.

٤. الفجوة: $2.0 / 0.1021 = 19.6$.

٥. سبب الفجوة: حدّ التكافؤ يفترض أن كل الإحداثيات الـ 262144 تتآمر في الاتجاه الأسوأ، أمّا الخطأ العشوائي فيتوزّع على كل الاتجاهات فيتوسّط جزءٌ كبيرٌ منه.

٦. التركيز: $\mathbb{P}(\|\Delta W\|_2 \ge 0.1021 + t) \le e^{-t^2/(2\sigma_e^2)}$؛ عند $t = 0.05$ $=: e^{-0.0025/(2\times 5.087\times 10^{-6})} = e^{-245.7}$ — احتمالٌ ضئيل.

النتيجة: الناظم الطيفي الفعلي لخطأ التكميم $0.10 \approx$ بتركيز شديد، مقابل حدّ أسوأ حالة $2.0 =$.

الربط بالذكاء الاصطناعي: هذه الفجوة بمعامل $20 \approx$ هي المبرّر الكامل لتحليل «التكميم بعد التدريب» (PTQ) بحدود احتمالية لا بحدود أسوأ حالة: فالخطأ العشوائي لا يتآمر. وهي أيضاً تفسّر لماذا تعمل الأوزان المُكَمَّمة إلى INT8 عملياً (بخطأ طيفي $0.1 \approx$) رغم أن التحليل الأسوأ-حالة يوحي بكارثة. القاعدة: **للأخطاء المنهجية (انحياز، سوء تكييف) استخدم حدود أسوأ حالة؛ وللأخطاء العشوائية (تكميم، ضغط، تقريب) استخدم التركيز.**

4.6.5 أخطاء شائعة في تركيز النواظم ولمّة JL

#	الخطأ الشائع	لماذا هو خطأ؟	التصحيح
1	افتراض أن JL تخفّض البعد دائماً	تتطلّب $k \gtrsim \varepsilon^{-2}\log n$؛ وقد يكون ذلك $> d$	قارن k بـ d قبل الاعتماد عليها (مثال 6-5.5)
2	الخلط بين $\pm\varepsilon$ على **المسافة** وعلى **مربّعها**	JL على المربّع؛ المسافة ضمن $\approx 1 \pm \varepsilon/2$	حدّد دائماً أيَّ كمية يُقاس التشويه عليها
3	استخدام ضمان «متجه واحد» لكل الأزواج	الفرق معامل $k \approx 6$ في $\ln(n^2/\delta)$ لا $\ln(2/\delta)$	استخدم $\ln(n^2/\delta)$
4	توقّع أن $\|W\|_F$ يعبّر عن سلوك الطبقة	$\|W\|_F \approx \sigma\sqrt{mn}$ و $\|W\|_2 \approx \sigma(\sqrt{m}+\sqrt{n})$	استخدم الطيفي للتحليل؛ والفجوة $\approx \sqrt{mn}/(\sqrt{m}+\sqrt{n})$
5	ظنّ أن ناظم المتجه العشوائي يتقلّب كثيراً	الانحراف النسبي $\approx 1/\sqrt{d}$	استخدم (35.5): التركيز أُسّي
6	تثبيت σ مع تغيير العرض	يجعل $\|W\|_2 \propto \sqrt{\text{width}}$	اختر $\sigma \propto 1/\sqrt{\text{fan_in}}$ أو $1/(\sqrt{m}+\sqrt{n})$
7	استخدام ناظم أقصى عنصر مع إسقاطات عشوائية	ليس متضاعفاً تحتياً ولا يتركّز بالطريقة نفسها	استخدم ℓ_2/الطيفي
8	افتراض أن التخفيض يحفظ **المتجه** لا كميةً قياسية	استعادة الاتجاه تتطلّب $k \geq d$	ميّز بين تقدير الناظم واستعادة المتجه (13-6.5)
9	تجاهل نسبة تركّز المتجه عند القناع العشوائي	للمتجهات القِمَمية يصل الانحراف إلى 33%	استخدم $\sqrt{(1-p)/p}\cdot\|x\|_\infty/\|x\|_2$
10	السعي إلى تحسين اعتماد k على ε أو n	الحدّ $\varepsilon^{-2}\log n$ مثاليّ	حسّن الثابت أو التكلفة الحسابية (Fast JL لا المرتبة)

مجموعة أ: المفردات ومتراجحات كوشي–شفارتس وهولدر

ت (5-1): بيّن أن الدالة $\|x\| = |x_1|$ على $\mathbb{R}^2$ **ليست** ناظماً. ما المسلّمة التي تنكسر؟

الجواب: تنكسر (N1): $\|(0,1)\| = 0$ لكن $(0,1) \neq 0$. هي شبه ناظم فقط.

ت (5-2): احسب $\|x\|_1$ و $\|x\|_2$ و $\|x\|_\infty$ لـ $x = (3,-4,0,1)^\top$ ورتّبها.

الجواب: 8، $\sqrt{26} = 5.099$، 4. الترتيب: $8 \geq 5.099 \geq 4$ ✓.

ت (5-3): تحقّق من كوشي–شفارتس لـ $x = (1,2,2)^\top$ و $y = (2,-1,2)^\top$، ثم احسب الزاوية.

الجواب: $\langle x,y\rangle = 2-2+4 = 4$؛ $\|x\|_2 = 3$، $\|y\|_2 = 3$؛ $4 \leq 9$ ✓؛ $\cos\theta = 4/9 = 0.4444 \Rightarrow \theta = 63.6°$.

ت (5-4): ما الأُسّ المترافق لـ $p = 3$؟ ثم استخدم هولدر لحساب سقف $\sum_i |x_i y_i|$ حيث $x = (1,2,3)$ و $y = (4,5,6)$.

الجواب: $q = 3/2$. $\|x\|_3 = (1+8+27)^{1/3} = 36^{1/3} = 3.3019$؛ $\|y\|_{3/2} = (4^{1.5}+5^{1.5}+6^{1.5})^{2/3} = (8+11.180+14.697)^{2/3} = (33.877)^{2/3} = 10.245$. **القيمة الفعلية** $= 4+10+18 = 32 \leq 33.83$ ✓. **السقف** $= 33.83$.

ت (5-5): ℓ_2 ثنوي نفسه. استخدم ذلك لحساب أقصى تغيّر في $w^\top x$ تحت $\|x\|_2 \leq 0.2$ عندما $\|w\|_2 = 7$.

الجواب: $|\Delta| \leq \|w\|_2\|x\|_2 = 7 \times 0.2 = 1.4$، ويُبلَغ بـ $x = 0.2\,w/\|w\|_2$.

ت (5-6): بيّن أن $\|x\|_1 \leq \sqrt{s}\|x\|_2$ حيث $s = |\operatorname{supp}(x)|$ باستخدام كوشي–شفارتس مباشرةً.

الجواب: $\sum_{i\in S}|x_i|\cdot 1 \leq \sqrt{\sum_{i\in S}x_i^2}\sqrt{|S|} = \sqrt{s}\|x\|_2$.

مجموعة ب: تكافؤ النواظم

ت (5-7): احسب حدود $\|x\|_1$ في $\mathbb{R}^{100}$ إذا كان $\|x\|_2 = 2$.

الجواب: $2 \le \|x\|_1 \le 10 \times 2 = 20$.

ت (5-8): متى يُبلَغ الحدّ الأعلى $\|x\|_1 = \sqrt{n}\|x\|_2$؟ ومتى الأسفل؟

الجواب: الأعلى عندما تتساوى كل $|x_i|$ (مثل $x = \mathbf{1}$)؛ والأسفل عندما يكون غير الصفري إحداثياً واحداً ($x = ce_i$).

ت (5-9): متجه متناثر في $\mathbb{R}^{10000}$ بـ $s = 25$ إحداثياً غير صفري و $\|x\|_2 = 5$. احسب حدّ $\|x\|_1$ المتناثر وقارنه بالكثيف.

الجواب: متناثر: $\le 5\sqrt{25} = 25$؛ كثيف: $5\sqrt{10000} = 500 \le$؛ تحسين بمعامل 20.

ت (5-10): إن كان $\|e_k\|_2 \le 0.8^k \|e_0\|_2$ و $n = 100$، فكم تكراراً إضافياً يكلّفه قياس الخطأ بـ ℓ_∞؟

الجواب: $\dfrac{\ln \sqrt{100}}{\ln(1/0.8)} = \dfrac{2.3026}{0.2231} = 10.32 \Rightarrow \approx 11$ تكراراً إضافياً.

ت (5-11): بيّن أن $\|x\|_\infty \le \|x\|_2 \le \|x\|_1 \le n\|x\|_\infty$ لكل $x \in \mathbb{R}^n$.

الجواب: الحدّان الأولان من (13.5)؛ والأخير من $|x_i| \le \|x\|_\infty$ لكل i فـ $\|x\|_1 = \sum |x_i| \le n\|x\|_\infty$.

ت (5-12): لماذا لا يعطي تنظيم $\|w\|_2$ تناثراً بينما يعطيه تنظيم $\|w\|_1$؟

الجواب: كرة ℓ_1 لها أركان حادّة على محاور الإحداثيات، فنقطة التماس مع مستوى القيد تقع غالباً على محور (إحداثيات صفرية)؛ وكرة ℓ_2 ملساء فنقطة التماس عامّة الموضع.

مجموعة ج: النواظم المصفوفية

ت (5-13): احسب $\|A\|_1$ و $\|A\|_\infty$ لـ $A = \begin{pmatrix} 1 & -2 \\ 3 & 1 \end{pmatrix}$.

الجواب: مجاميع الأعمدة: 4 و $3 \Rightarrow \|A\|_1 = 4$؛ مجاميع الصفوف: 3 و $4 \Rightarrow \|A\|_\infty = 4$.

ت (5-14): احسب $\|A\|_2$ للمصفوفة نفسها.

الجواب: $A^\top A = \begin{pmatrix} 10 & 1 \\ 1 & 5 \end{pmatrix}$، الأثر 15، المحدِّد 49؛ $\lambda = \frac{15 \pm \sqrt{225-196}}{2} = \frac{15 \pm 5.3852}{2} \Rightarrow \lambda_1 = 10.1926$؛ $\|A\|_2 = \sqrt{\lambda_1} = 3.1926$.

ت (5-15): تحقّق أن $\rho(A) \le \|A\|_2$ للمصفوفة نفسها.

الجواب: القيم الذاتية: $\lambda = 1 \pm i\sqrt{6} \Rightarrow \lambda^2 - 2\lambda + 7 = 0$، $|\lambda| = \sqrt{7} = 2.6458 \le 3.1926$ ✓.

ت (5-16): بيّن أن $\|A\|_2 \le \sqrt{\|A\|_1 \|A\|_\infty}$ للمصفوفة نفسها.

الجواب: $\sqrt{4 \times 4} = 4 \ge 3.1926$ ✓.

ت (5-17): إن كان $\|A\|_2 = 0.4$، فاحدُد $\|(I - A)^{-1}\|_2$ وفسّر معنى الرقم.

الجواب: $\le \frac{1}{1-0.4} = 1.667$. المعنى: تضخّم التدرّج عبر طبقة ضمنية لا يتجاوز 1.667 ضعفاً.

ت (5-18): مصفوفة A قيمها المفردة $(10,\ 2,\ 0.5)$. احسب $\kappa_2(A)$ والخطأ النسبي الأقصى في الحل عند اضطراب نسبي 10^{-4}.

الجواب: $\kappa_2 = 10/0.5 = 20 \implies$ خطأ نسبي $\le 20 \times 10^{-4} = 2 \times 10^{-3}$ أي 0.2%.

ت (5-19): بيّن أن $\|A\|_{\max}$ ليس متضاعفاً تحتياً بمثال.

الجواب: $A = B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$: $\|A\|_{\max}\|B\|_{\max} = 1$ لكن $\|AB\|_{\max} = 2 > 1$.

ت (5-20): لماذا $\|I_n\|_F = \sqrt{n}$ بينما $\|I_n\|_2 = 1$؟

الجواب: الفرونيوسي يجمع مربّعات كل العناصر (n عنصراً قيمة كلٍّ 1)؛ والطيفي يقيس أقصى تمديد (والتحويلُ الوحدوي لا يمدّد شيئاً).

مجموعة د: نواظم شاتن وفون نيومان

ت (5-21): مصفوفة قيمها المفردة $(6,\ 3,\ 1)$. احسب $\|A\|_*$ و $\|A\|_F$ و $\|A\|_2$ والرتبة الفعّالة.

الجواب: 10؛ $\sqrt{46} = 6.782$؛ 6؛ $\text{erank} = 100/46 = 2.17$.

ت (5-22): مصفوفة شبه موجبة قيمها الذاتية $(9,\ 4,\ 1)$. ما ناظمها النووي بلا SVD؟

الجواب: $\|A\|_* = \text{tr}(A) = 14$ (لأن $A \succeq 0$ فالقيم المفردة = القيم الذاتية).

ت (5-23): احسب سقف فون نيومان لـ $\sigma(A) = (5, 2)$ و $\sigma(B) = (3, 1)$. ما القيمة إذا كانت المحاور متطابقة؟

الجواب: $5 \times 3 + 2 \times 1 = 17$؛ وبالمحاور المتطابقة $|\text{tr}(A^\top B)| = 17$ (يبلغ السقف).

ت (5-24): الترتيب المعكوس يعطي ماذا؟ قارن.

الجواب: $5 \times 1 + 2 \times 3 = 11$ (الأدنى)؛ فالمدى $[11, 17]$.

ت (5-25): تحديث LoRA رتبته 1: $\Delta W = uv^\top$ بـ $\|u\|_2 = 3$ و $\|v\|_2 = 4$. احسب نواظمه الثلاثة.

الجواب: $\sigma = (12) \implies \|\Delta W\|_* = \|\Delta W\|_F = \|\Delta W\|_2 = 12$.

ت (5-26): بيّن أن $|\text{tr}(A^\top B)| \le \|A\|_2 \|B\|_*$ هي حالة خاصة من هولدر لشاتن.

الجواب: بـ $(p, q) = (\infty, 1)$: $\frac{1}{\infty} + \frac{1}{1} = 1$ ✓؛ و $\|A\|_{S_\infty} = \|A\|_2$، $\|B\|_{S_1} = \|B\|_*$.

مجموعة هـ: التركيز وJL

ت (5-27): متجه غاوسي في $\mathbb{R}^{10000}$. ما ناظمه المتوقَّع؟ وما احتمال انحرافه بـ 20؟

الجواب: $\sqrt{10000} = 100$؛ $\mathbb{P} \le 2e^{-200} \approx 2.8 \times 10^{-87}$ — صفر عملياً.

ت (5-28): مصفوفة $W \in \mathbb{R}^{2048\times 2048}$ بمدخلات $\mathcal{N}(0,\, 1/2048)$. ما ناظمها الطيفي المتوقَّع؟

الجواب: $\sigma = 1/\sqrt{2048} = 0.022097$؛ $\mathbb{E}\|W\|_2 \le 0.022097 \times (45.255 + 45.255) = 2.0$.

ت (5-29): ما $\|W\|_F$ النموذجي للمصفوفة نفسها؟ وما معامل الفجوة؟

الجواب: $\sigma\sqrt{mn} = 0.022097 \times 2048 = 45.25$؛ معامل الفجوة $= 45.25/2 = 22.6 = \sqrt{2048}/2$ ✓.

ت (5-30): $n = 10^4$ نقطة و $\varepsilon = 0.2$ و $\delta = 0.05$. احسب k المطلوب لـ JL.

الجواب: $\varepsilon^2 - \varepsilon^3 = 0.04 - 0.008 = 0.032$؛ $\ln(n^2/\delta) = \ln(10^8/0.05) = \ln(2 \times 10^9) = 21.416$؛ $k \ge 4 \times 21.416/0.032 = 2677 \Rightarrow k = 2677$.

1.8.5 جدول النظريات الخمس

#	النظرية	الصيغة الحاكمة	متى تستخدمها؟
2.5	كوشي–شفارتس / هولدر / مينكوفسكي	$\lvert\langle x,y\rangle\rvert \le \|x\|_p\|y\|_q$ بالترافق $\frac{1}{p}+\frac{1}{q}=1$	لضبط أيّ جداء داخلي: التشابه، القربات، الحدود الأساسية
3.5	تكافؤ النواظم	$c\|x\|_\alpha \le \|x\|_\beta \le C\|x\|_\alpha$، والثوابت تعتمد على n (أو s)	للتحويل بين النواظم، ولتفسير «ثمن البعد»
4.5	النواظم المستحثة والتضاعف التحتي	$\|AB\| \le \|A\|\|B\|$، و $\rho(A) \le \|A\|$، و $\|A\|_2 = \sigma_1$	لتحليل الاستقرار، وتراكم الأخطاء، وليبشيتز
5.5	شاتن وفون نيومان	$\lvert\mathrm{tr}(A^\top B)\rvert \le \langle\sigma(A),\sigma(B)\rangle \le \|A\|_{S_p}\|B\|_{S_q}$	للرتبة المنخفضة، ولضرب مصفوفتين، وللرتبة الفعّالة
6.5	تركيز النواظم وJL	$k = \mathcal{O}(\varepsilon^{-2}\log n)$ يحفظ كل المسافات؛ و $\|W\|_2 \approx \sigma(\sqrt{m}+\sqrt{n})$	للأبعاد العالية، وللأخطاء العشوائية، وللإسقاطات

2.8.5 خمسة مبادئ حاكمة

١. **الناظم ليس مقياساً محايداً — هو قرار.** اختيار الناظم يحدّد شكل كرة الوحدة، وشكل الكرة يحدّد نوع الحل (تناثر، رتبة منخفضة، استقرار، أسوأ حالة).

٢. **الناظم الثنوي هو «ما يقابل» الناظم الأصلي.** كل حدّ هو جداء: $\|x\|_* \cdot \|w\|$؛ ولا معنى لتحسين أحدهما دون الآخر.

٣. **التكافؤ يحمي «المقاربية»، والثوابت تحكم «السرعة».** الرقم ρ لا يتغيّر بتغيير الناظم، لكن عدد الخطوات يتغيّر بمقدار $\frac{\ln\sqrt{n}}{\ln(1/\rho)}$.

٤. **المصفوفة مشغّل لا قائمة.** حلّل بـ $\|A\|_2$؛ واحسب بـ $\|A\|_F$ أو بحدود رخيصة؛ ولا تخلط بينهما بلا معامل.

٥. **للأخطاء المنهجية حدودُ أسوأ حالة؛ وللأخطاء العشوائية حدودُ التركيز.** الخلط بينهما ينتج إمّا كارثةً متوهّمة (مبالغة) وإمّا أماناً زائفاً (تفاؤل).

3.8.5 الطريق إلى الأجزاء التالية

الموضوع في هذا الفصل	أين يظهر لاحقاً؟
النواظم والمتراجحات	**الجزء الرابع (التحسين):** تحليل التقارب، والتدرّج المقيَّد، وثوابت ليبشيتز للمُحسِّنات
الناظم الثنوي و $\|w\|\|x\|_*$	**الجزء السادس (نظرية التعلّم):** تعقيد راديماخر، وحدود التعميم القائمة على الهامش
$\|W\|_2$ والاستقرار	**الجزء السابع (رياضيات التعلّم العميق):** الشبكات مقيَّدة ليبشيتز، والتطبيع الطيفي، وNTK
الرتبة الفعّالة والنووي	**الجزء السابع:** الضغط، والتحليل الطيفي للتمثيلات، وانهيار التمثيل
تركيز النواظم وJL	**الجزء الثامن:** الإسقاطات العشوائية، والطوبولوجيا الحسابية، والتضمينات منخفضة البعد
مسافات على التوزيعات	**الجزء الخامس (نظرية المعلومات) والجزء الثامن (نقل الأمثل):** TV، KL، Wasserstein

الفصل القادم: التحليل العددي والاستقرار الحسابي — حيث نحوّل متراجحات هذا الفصل إلى **خوارزميات**: كيف نحسب SVD و QR و factorization بثبات، وكيف تتراكم أخطاء النقطة العائمة، ولماذا يُعدّ رقم الحالة — لا دقة الحاسوب — هو الحدّ الحقيقي لما يمكن حسابه.

الرمز	المعنى	القسم
$\|\cdot\|$	ناظم عام	1.5
$\|\cdot\|_p$	ناظم ℓ_p	1.5
$\|\cdot\|_1,\ \|\cdot\|_2,\ \|\cdot\|_\infty$	مانhattan، إقليدي، تشيبيشيف	1.5
$\|\cdot\|_G$	ناظم آتٍ من مصفوفة قياس G	1.5
$d(x,y)$	مسافة / مترية	1.5
$\langle x,y\rangle$	ضرب داخلي	1.5
$\|\cdot\|_*$	الناظم الثنوي	2.5
p, q	أُسّان مترافقان: $\frac{1}{p}+\frac{1}{q}=1$	2.5
θ	الزاوية بين متجهين	2.5
a, b	متغيّرا لمّة يونغ	2.5
$c,\ C$	ثابتا التكافؤ بين ناظمين	3.5
S_α	سطح كرة الوحدة	3.5
s	مستوى التناثر $(\|\operatorname{supp}(x)\|)$	3.5
$\operatorname{supp}(x)$	دعم المتجه	3.5
$\|A\|_{\alpha\to\beta}$	ناظم مستحث من α إلى β	4.5
$\|A\|_2$	الناظم الطيفي $= \sigma_1$	4.5
$\|A\|_1$	ناظم المشغّل ℓ_1 = أكبر مجموع عمود	4.5
$\|A\|_\infty$	ناظم المشغّل ℓ_∞ = أكبر مجموع صف	4.5
$\|A\|_F$	الناظم الفروبنيوسي	4.5
$\|A\|_{\max}$	ناظم أقصى عنصر مطلق	4.5
$\rho(A)$	نصف القطر الطيفي	4.5
$\kappa(A)$	رقم الحالة	4.5
$\sigma_i(A)$	القيمة المفردة رقم i	4.5
r	الرتبة	4.5
$\|A\|_{S_p}$	ناظم شاتن من الرتبة p	5.5
$\|A\|_*$	الناظم النووي $= \|A\|_{S_1}$	5.5
$\operatorname{tr}(\cdot)$	الأثر	5.5
$U,\ V$	المصفوفتان الوحديّتان في SVD	5.5
Σ	مصفوفة القيم المفردة القطرية	5.5
$\operatorname{erank}(A)$	الرتبة الفعّالة $= \|A\|_*^2/\|A\|_F^2$	5.5
R	مصفوفة إسقاط عشوائي $k\times d$	6.5
k	البعد بعد الإسقاط	6.5
ε	تشويه JL (على مربّع المسافة)	6.5
δ	احتمال الفشل	6.5
χ^2_k	توزيع مربّع كاي بـ k درجة حرية	6.5
g	متجه غاوسي قياسي	6.5
σ	انحراف معياري لمدخلات المصفوفة العشوائية	6.5
d_0	بُعد الفضاء الجزئي في تضمين الفضاءات الجزئية	6.5

١. A.-L. Cauchy, (1821). *Cours d'Analyse de l'École Polytechnique Royale* — متراجحة كوشي–شفارتس.

٢. H. A. Schwarz, (1888). *Über ein Flächeninhalts kleinsten Flächen betreffendes Problem der Variationsrechnung*.

٣. O. Hölder, (1889). «Über einen Mittelwerthssatz». *Nachrichten Göttinger*.

٤. H. Minkowski, (1896). *Zahlen der Geometrie*.

٥. H. W. Young, (1912). «On classes of functions and their Fourier series». *Proc. R. Soc. A*.

٦. G. Pólya, E., J. Littlewood, H., G. Hardy, (1934). *Inequalities*. University Cambridge Press — المرجع الكلاسيكي للمتراجحات.

٧. R. Bellman, F., E. Beckenbach, (1961). *An Introduction to Inequalities*. MAA.

٨. M. J. Steele, (2004). *The Cauchy–Schwarz Master Class*. University Cambridge Press.

٩. R. C. Johnson, A., R. Horn, (2012). *Matrix Analysis*, 2nd ed. University Cambridge Press — النواظم المصفوفية ونواظم شاتن.

١٠. F. C. Loan, Van H., G. Golub, (2013). *Matrix Computations*, 4th ed. Johns Hopkins — النواظم وأرقام الحالة.

١١. J. N. Higham, (2002). *Accuracy and Stability of Numerical Algorithms*, 2nd ed. SIAM.

١٢. D. Bau, N., L. Trefethen, (1997). *Numerical Linear Algebra*. SIAM.

١٣. J. Neumann, von (1937). «Some matrix-inequalities and metrization of matric-space». *Univ. Tomsk Rev.*

١٤. L. Mirsky, (1960). «Symmetric gauge functions and unitarily invariant norms». *Q. J. Math.*

١٥. R. Bhatia, (1997). *Matrix Analysis*. Springer — نواظم شاتن ومتراجحات الأثر.

١٦. M. Fazel, (2002). *Matrix Rank Minimization with Applications*, PhD Thesis, Stanford — النووي غلافاً مقعّباً للرتبة.

١٧. A. P. Parrilo, M., Fazel, B., Recht, (2010). «Guaranteed minimum-rank solutions via nuclear norm minimization». *SIAM Rev.*

١٨. B. Recht, J., E. Candès, (2009). «Exact matrix completion via convex optimization». *Found. Comput. Math.*

١٩. T. Tao, J., E. Candès, (2010). «The power of convex relaxation: near-optimal matrix completion». *IEEE Trans. Inform. Theory*.

٢٠. J. Lindenstrauss, B., W. Johnson, (1984). «Extensions of Lipschitz mappings into a Hilbert space». *Contemp. Math.* 26.

٢١. A. Gupta, S., Dasgupta, (2003). «An elementary proof of a theorem of Johnson and Lindenstrauss». *Random Structures & Algorithms*.

٢٢. N. Alon, (2003). «Problems and results in extremal combinatorics — I». *Discrete Math*. JL. حدود سفلى لـ

٢٣. J. Nelson, G., K. Larsen, (2017). «Optimality of the Johnson–Lindenstrauss lemma». *FOCS*.

٢٤. Y. Gordon, (1985). «Some inequalities for Gaussian processes and applications». *Israel J. Math*.

٢٥. Q. Y. Yin, D., Z. Bai, (1993). «Limit of the smallest eigenvalue of a large-dimensional sample covariance matrix». *Ann. Probab*.

٢٦. R. Vershynin, (2018). *High-Dimensional Probability*. Cambridge University Press — التركيز والمصفوفات العشوائية.

٢٧. Boucheron, S., Lugosi, G., Massart, P. (2013). *Concentration Inequalities*. Oxford University Press.

٢٨. P. D. Woodruff, (2014). «Sketching as a Tool for Numerical Linear Algebra». *Found. Trends Theor. Comput. Sci*.

٢٩. B. Recht, A., Rahimi, (2007). «Random features for large-scale kernel machines». *NeurIPS*.

٣٠. W. M. Mahoney, (2011). «Randomized Algorithms for Matrices and Data». *Found. Trends Mach. Learn*.

تمّ الفصل الخامس. في الفصل السادس ننتقل من **متراجحات القياس** إلى **خوارزميات الحساب**: كيف نحوّل هذه المتراجحات إلى عمليات مستقرّة عددياً، وكيف نقرأ «ماذا يحدث فعلاً» داخل حساب النقطة العائمة.

التحليل العددي والاستقرار الحسابي

الهدف من الفصل

أن تفهم **ماذا يحدث فعلاً** داخل الحاسوب حين يحسب. في الفصل الخامس أعطينا متراجحات «مثالية» على أعداد حقيقية دقيقة لانهائياً. هذا الفصل يسأل السؤال الذي يُسقط كل متراجحة جميلة على أرض الواقع: **ماذا لو كان كل رقم في الحاسوب يحمل خطأً صغيراً؟** متى يبقى الخطأ صغيراً؟ ومتى ينفجر فيُخرج نموذجاً «يتعلّم» لكن نتائجه هراء؟

لماذا هذا الفصل هو «فجوة الواقع» في الكتاب؟

كل خوارزمية في تعلم الآلة — التدرّج العكسي، تربيع المربعات الصغرى، انتباه (attention) المحوّلات، تهيئة الأوزان، القياس الكمّي (quantization)، التدريب بالدقة المختلطة (mixed precision)، حساب الانتروبيا المتقاطعة — هي في نهاية المطاف **سلسلة من عمليات النقطة العائمة**. والفرق بين نموذج يتدرّب ونموذج يعطي NaN من الخطوة الأولى ليس فرقاً في «المعرفة الرياضية» بل في **الاستقرار العددي**.

الظاهرة في الذكاء الاصطناعي	السبب العددي
ظهور NaN فجأة أثناء التدريب	فيضان (overflow) في exp أو قسمة $0/0$
loss لا ينزل مع أنه محسوب صحيحاً	إلغاء كارثي أو تراكم خطأ في الجمع على دفعات ضخمة
نتائج غير قابلة للتكرار بين CPU و GPU	ترتيب الجمع مختلف $\Rightarrow$ أخطاء تقريب مختلفة (غير تجميعية)
fp16 ينفجر و fp32 يعمل	فقدان الخانات: فقدنا $\log_{10}\kappa$ خانات بسبب رقم الحالة
تدريب غير مستقر مع طبقات عميقة	حاصل نواظم المشغّل $\prod_k \|W_k\|_2$ — تضخّم أسي
حلّ المربعات الصغرى «دقيق» نظرياً وخطأ عملياً	المعادلات السوية تربّع رقم الحالة — $\kappa(A^\top A)=\kappa(A)^2$
انهيار الأوزان إلى صفر (underflow) في fb16	أصغر عدد مطبّعي 1.18×10^{-38} والتدرّجات الصغيرة تختفي
فروق شاسعة بين إطارين (PyTorch/TF) في الأرقام العشرية	ترتيب العمليات وخوارزميات الجمع (Kahan/pairwise)

خريطة الفصل

القسم	الموضوع	القوانين/النظريات	عدد الأمثلة المحلولة
1.6	المفردات: نموذج النقطة العائمة، الخطأ الأمامي/الخلفي، التكييف	(1.6)–(7.6)	—
2.6	**القانون الأساسي لتحليل الخطأ**: الخطأ الأمامي $\lesssim \kappa\times$ الخطأ الخلفي	(8.6)–(13.6)	15
3.6	**الإلغاء الكارثي وتراكم الخطأ في الجمع** (Kahan)	(14.6)–(19.6)	15
4.6	**استقرار التحويلات المتعامدة** و QR Householder	(20.6)–(25.6)	15
5.6	**تكييف المربعات الصغرى**: $\kappa(A^\top A)=\kappa(A)^2$ وحدّ غولوب–ويلكنسون	(26.6)–(31.6)	15
6.6	**عامل النموّ في LU** والتنقيح التكراري (iterative refinement)	(32.6)–(37.6)	15
7.6	**استقرار softmax/log-sum-exp** والدقة المختلطة	(38.6)–(43.6)	15
8.6	تمارين محلولة ومفتوحة (30 تمريناً)	—	—
9.6	خلاصة الفصل	—	—
10.6	فهرس الرموز	—	—
11.6	المراجع	—	—

كيف تقرأ هذا الفصل

كل نظرية تأتي في **أربع طبقات** إلزامية:

١. **الصياغة الرياضية الرسمية** داخل كتلة LaTeX مستقلة باتجاه LTR.

٢. **جدول الرموز:** كل رمز ومعامل يُشرح منفرداً.

٣. **رسم هندسي** (SVG) يشرح المعنى البصري.

٤. **خمسة عشر مثالاً محلولاً من الواقع** — كل مثال: المعطيات ← المطلوب ← الحل خطوة بخطوة ← النتيجة ← الربط بالذكاء الاصطناعي.

ثم: برهان، شروط صحّة، أخطاء شائعة، ثم تمارين.

1.1.6 نموذج النقطة العائمة (floating-point model)

الحاسوب لا يخزّن الأعداد الحقيقية، بل مجموعة منتهية $\mathbb{F} \subset \mathbb{R}$. عملية التقريب $\mathrm{fl} : \mathbb{R} \to \mathbb{F}$ تخضع للنموذج القياسي التالي (نموذج ويلكنسون):

$$\mathrm{fl}(x \ \mathrm{op} \ y) = (x \ \mathrm{op} \ y)(1+\delta), \qquad |\delta| \le u, \qquad \mathrm{op} \in \{+, -, \times, \div\} \tag{1.6}$$

$$u = \begin{cases} \frac{1}{2}\beta^{1-t} & \text{round-to-nearest (أكثر الحالات)} \\ \beta^{1-t} & \text{round-toward-zero} \end{cases} \tag{2.6}$$

الرمز	المعنى	القيمة النموذجية
$\mathrm{fl}(\cdot)$	دالة التقريب إلى أقرب عدد مُمثَّل في $\mathbb{F}$	—
x, y	الأعداد الحقيقية الدقيقة المُدخلة في العملية	—
op	إحدى العمليات الحسابية الأربع الأساسية	$+, -, \times, \div$
δ	الخطأ النسبي المُدخل في **عملية واحدة**	$\lvert\delta\rvert \le u$
u	**وحدة التقريب** (unit roundoff) — نصف الفجوة النسبية بين عددين متجاورين	انظر الجدول أدناه
β	أساس التمثيل (دائماً 2 في الأجهزة الحديثة)	2
t	عدد خانات الجوهر (significand/precision) بالأساس β	24 في fp32، 53 في fp64
$\frac{1}{2}$	معامل «أقرب جار»: أقصى انحراف هو نصف المسافة بين جارين	—

قيم عملية يجب حفظها:

الصيغة	t	$u = \frac{1}{2}\beta^{1-t}$	أصغر مطبّعي موجب	أكبر عدد	الخانات العشرية الصحيحة
fbloat16	8	3.91×10^{-3}	1.18×10^{-38}	3.39×10^{38}	≈ 2
fp16	11	4.88×10^{-4}	6.10×10^{-5}	65504	≈ 3
fp32	24	5.96×10^{-8}	1.18×10^{-38}	3.40×10^{38}	≈ 7
fp64	53	1.11×10^{-16}	2.23×10^{-308}	1.80×10^{308}	≈ 16
tf32	11 (مدى fp32)	4.88×10^{-4}	—	—	≈ 3

تنبيه مهم: كثير من المصادر تسمّي $\varepsilon_{\text{machine}} = \beta^{1-t}$ (الفجوة الكاملة) وحدةَ التقريب، وبعضها يسمّي $u = \frac{1}{2}\beta^{1-t}$. في هذا الكتاب نعتمد $u = \frac{1}{2}\beta^{1-t}$ (اتفاقية Higham)، لأنها حدّ الخطأ النسبي الفعلي لعملية واحدة. الفرق بينهما معامل 2 فقط — لا يغيّر أي استنتاج نوعي.

ثلاث خصائص جوهرية تُترجَم إلى قواعد عملية:

١. **عدم التجميعية (non-associativity):** $(a+b)+c \neq a+(b+c)$ في الحساب المُمثَّل. لهذا تختلف نتائج CPU عن GPU عن TPU.

٢. **عدم التوزيعية:** $a(b+c) \neq ab+ac$ بالضبط.

٣. **الامتصاص (absorption):** إذا كان $|b| < u|a|$ فإن $\mathrm{fl}(a+b) = a$ — أي أن b **يختفي تماماً.** هذه هي الآلية التي تجعل التحديثات الصغيرة تضيع في التدريب بالدقة المنخفضة.

2.1.6 الخطأ المطلق، النسبي، الأمامي، والخلفي

$$e_{\text{abs}} = |\hat{x} - x|, \qquad e_{\text{rel}} = \frac{|\hat{x} - x|}{|x|} \quad (x \neq 0) \tag{3.6}$$

$$\underbrace{\hat{y} = f(x) + \Delta y}_{\text{تحليل أمامي (forward)}} \quad \Longleftrightarrow \quad \underbrace{\hat{y} = f(x + \Delta x)}_{\text{تحليل خلفي (backward)}} \tag{4.6}$$

الرمز	المعنى
x	المُدخل الحقيقي الدقيق (الذي نريده)
$\hat{x}$	المُدخل أو المخرج **المحسوب فعلاً** في الحاسوب
e_{abs}	الخطأ المطلق — بوحدات الكمية نفسها
e_{rel}	الخطأ النسبي — بلا وحدات، وهو المقياس المفيد في المقارنات
f	الدالة/الخوارزمية الرياضية المثالية
$\hat{y}$	المخرج المحسوب فعلاً
Δy	**الخطأ الأمامي:** كم أخطأ المخرج؟
Δx	**الخطأ الخلفي:** بأقلّ قدرٍ كم يجب أن نغيّر المُدخل لكي نُبرّر المخرج المحسوب؟

لماذا التحليل الخلفي هو الفكرة العبقرية في القرن العشرين؟ لأن السؤال «كم أخطأنا؟» سؤال صعب (يحتاج معرفة الحلّ الدقيق)، أمّا السؤال «هل أخطأنا؟» فسهل: نتحقّق أنّ المخرج هو **الحلّ الدقيق لمسألة قريبة.** ويلكنسون حول هذا المبدأ إلى أداة: الخوارزمية جيدة إذا كان خطؤها الخلفي من رتبة u — أي أنها تحلّ مسألة قريبة من مسألتنا بمسافة u، وهي مسافة لا يمكن لأي خوارزمية أن تتجاوزها أصلاً لأن مُدخلاتها نفسها مخزّنة بخطأ u.

3.1.6 رقم الحالة (condition number) — مقياس حساسية المسألة

$$\mathrm{cond}(f, x) = \lim_{\varepsilon \to 0} \sup_{|\Delta x| \leq \varepsilon |x|} \frac{|f(x+\Delta x) - f(x)|/|f(x)|}{|\Delta x|/|x|} = \frac{|x\, f'(x)|}{|f(x)|} \tag{5.6}$$

$$\kappa(A) = \|A\| \cdot \|A^{-1}\|, \qquad \kappa_2(A) = \frac{\sigma_1(A)}{\sigma_{\min}(A)} \tag{6.6}$$

الرمز	المعنى
$\mathrm{cond}(f, x)$	رقم الحالة النسبي للمسألة f عند النقطة x
ε	مقدار الاضطراب النسبي في المُدخل (نسبة مئوية)
Δx	اضطراب صغير في المُدخل
$f'(x)$	مشتقة f عند x — معدّل تضخّم الخطأ محلياً
$\kappa(A)$	رقم حالة المصفوفة A (غير المفردة) بالناظم $\|\cdot\|$
$\sigma_1, \sigma_{\min}$	أكبر وأصغر قيمة مفردة لـ A
$f(x) = 0$	إذا كان المخرج صفراً فإن (5.6) غير مُعرَّف — المسألة «سيئة التكييف بلا حدّ»

الفرق الحاسم الذي يجب أن يُحفظ:

المفهوم	يصف	من يتحكّم به؟	هل يمكن إصلاحه؟
التكييف (conditioning)	المسألة نفسها: كم تتضخّم الأخطاء؟	صياغة المسألة + البيانات	لا — بإعادة الصياغة (reparameterization) فقط
الاستقرار (stability)	الخوارزمية: كم خطأً تُدخله هي؟	طريقة الحساب	نعم — باختيار خوارزمية أفضل

مثال كلاسيكي على الفرق: حساب $f(x) = x^2$ مسألة ممتازة التكييف ($\text{cond} = 2$). لكن خوارزمية حسابها بالجمع المتكرّر $x^2 = x + x + \cdots + x$ (x مرّة) خوارزمية **سيئة**. التكييف سمة المسألة؛ الاستقرار سمة الخوارزمية.

4.1.6 أداة التجميع: ثابت γ_n

حين نركّب n عملية، تتضاعف معاملات $(1+\delta_i)$. الأداة القياسية لضبط هذا الحاصل:

$$\prod_{i=1}^{n}(1+\delta_i)^{s_i} = 1+\theta_n, \qquad |\theta_n| \le \gamma_n, \qquad \gamma_n = \frac{nu}{1-nu} \tag{7.6}$$

الرمز	المعنى
δ_i	خطأ التقريب في العملية i، مع $\lvert\delta_i\rvert \le u$
s_i	الأُسّ ± 1 (جمع/طرح أم ضرب/قسمة)
θ_n	الخطأ النسبي المُجمَّع بعد n عملية
γ_n	الحدّ الأعلى ل $\lvert\theta_n\rvert$
n	عدد العمليات
شرط الاستعمال	$nu < 1$ — وإلا فالحدّ بلا معنى (تدهور كامل)

النتيجة المباشرة الأهم (حدّ الجمع):

$$\left|\mathrm{fl}\left(\sum_{i=1}^{n} x_i\right) - \sum_{i=1}^{n} x_i\right| \le \gamma_{n-1} \sum_{i=1}^{n} |x_i| \tag{7b.6}$$

وهذا يعني أن خطأ الجمع ينمو **خطياً** مع n — وهذا بالضبط ما يعالجه جمع كاهان في §3.6.

5.1.6 خلاصة المفردات في خمس قواعد

١. الحاسوب يحسب بـ $\mathrm{fl}(x \mathbin{\mathrm{op}} y) = (x \mathbin{\mathrm{op}} y)(1+\delta)$ مع $|\delta| \le u$.

٢. الخطأ **الخلفي** يقول: أخطأنا في المُدخل بمقدار u؛ والخطأ **الأمامي** يقول: أخطأنا في المخرج بمقدار κu.

٣. لا خوارزمية — مهما بلغت عبقريتها — تستطيع أن تعطي خطأً أمامياً أصغر من κu.

٤. **الخانات المفقودة** $\approx \log_{10}\kappa$.

٥. الفيضان (overflow) يقتل بـ inf، والانهيار (underflow) يقتل بـ 0، والإلغاء (cancellation) يقتل بصمت.

1.2.6 الصياغة الرياضية الرسمية

النظرية 1.6 (قانون الحالة الأساسي — Error of Law Fundamental ،Analysis) لتكن f دالة قابلة للاشتقاق، ولتكن $\hat{x} = x + \Delta x$ مُدخلاً مضطرباً بخطأ نسبي $\|\Delta x\|/\|x\| \le \varepsilon$. عندئذٍ:

<

1. **حدّ التضخّم (الخطأ الأمامي بدلالة الخلفي):**

<

$$\frac{|\hat{y} - f(x)|}{|f(x)|} \;\le\; \operatorname{cond}(f, x) \cdot \frac{|\Delta x|}{|x|} + \mathcal{O}(\varepsilon^2), \qquad \operatorname{cond}(f, x) = \frac{|x\, f'(x)|}{|f(x)|} \tag{8.6}$$

<

2. **نسخة النظم الخطية** ($Ax = b$ مع اضطرابات في A و b معاً):

<

$$\frac{\|\hat{x} - x\|}{\|x\|} \;\le\; \frac{\kappa(A)}{1 - \kappa(A)\,\frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right) \tag{9.6}$$

<

3. **قاعدة الدقّة (accuracy rule)** — «لا خوارزمية تتجاوز رقم الحالة»: لأيّ خوارزمية مستقرّة خلفياً تعمل بدقّة u:

<

$$\text{err rel. forward} \;\approx\; \kappa(A)\, u, \qquad \#\text{digits correct} \;\approx\; -\log_{10}\!\big(\kappa(A)\, u\big) \tag{10.6}$$

<

4. **المسافة إلى المفردية** (رقم الحالة معناه الهندسي):

<

$$\min\big\{ \|\Delta A\|_2 :\; A + \Delta A \text{ singular} \big\} \;=\; \sigma_{\min}(A) \;=\; \frac{\|A\|_2}{\kappa_2(A)} \tag{11.6}$$

<

5. **خصائص رقم الحالة المصفوفي:**

<

$$\kappa(A) \geq 1, \qquad \kappa(\alpha A) = \kappa(A), \qquad \kappa_2(Q) = 1 \ (Q \text{ متعامدة}), \qquad \kappa(AB) \leq \kappa(A)\kappa(B) \tag{12.6}$$

<

6. **حدّ الاستحالة** — لماذا لا يُجدي تغيير الخوارزمية إذا كانت المسألة سيئة التكييف: بما أن المصفوفة المخزّنة أصلاً هي $\hat{A} = A + \Delta A$ مع $\|\Delta A\| \leq u\|A\|$، فإن **أفضل خوارزمية يمكن تخيّلها** (حلّ دقيق تماماً للمصفوفة المخزّنة) تعطي:

<

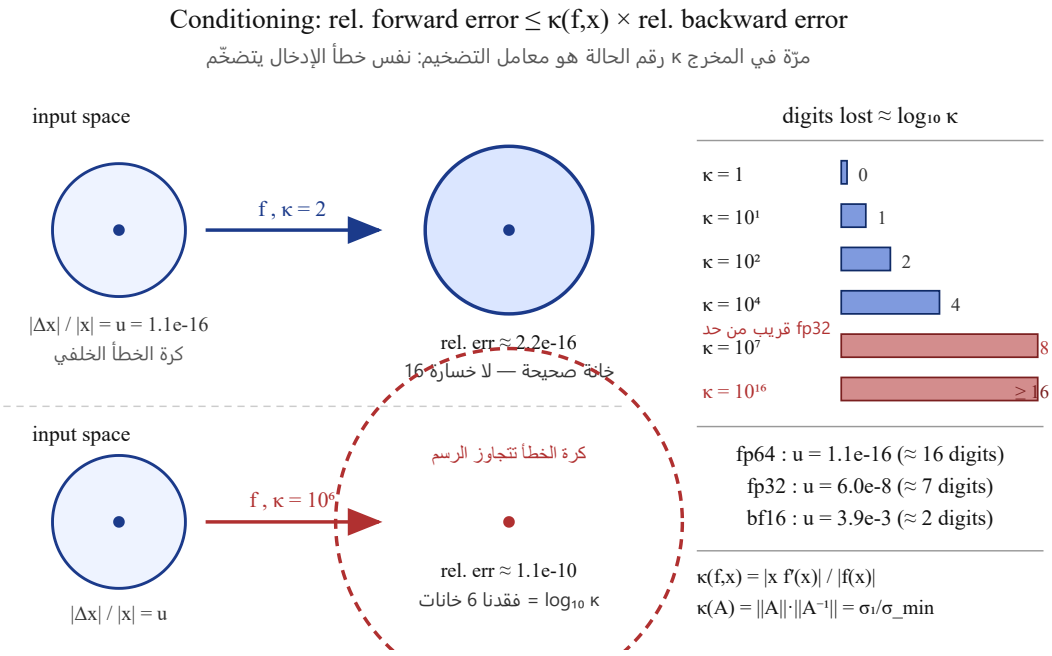
$$\frac{\|\hat{x} - x\|}{\|x\|} \;\leq\; \kappa(A)\, u + \mathcal{O}(u^2), \qquad \text{وهذا الحدّ مُحقَّق (attained)} \tag{13.6}$$

2.2.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
f	المسألة/الدالة الرياضية المثالية	قابلة للاشتقاق عند x
x	المُدخل الدقيق (الذي نريد حلّ المسألة عنده)	$x \neq 0$
$\hat{x}$	المُدخل المضطرب = المُدخل المخزّن فعلاً	$\hat{x} = x + \Delta x$
Δx	**الخطأ الخلفي** — الاضطراب في المُدخل	من تقريب التخزين أو من خطأ الحساب
ε	سقف الخطأ النسبي الخلفي: $\|\Delta x\|/\|x\| \leq \varepsilon$	عادة $\varepsilon = u$ أو $\varepsilon = \gamma_n$
$\hat{y}$	المخرج المحسوب	$\hat{y} = f(\hat{x})$
$\mathrm{cond}(f, x)$	رقم الحالة النسبي **للمسألة** عند x	معامل التضخّم
$f'(x)$	المشتقة — معدّل تضخّم الاضطراب محلياً	في الأبعاد المتعددة: اليعقوبية $J_f(x)$
$\mathcal{O}(\varepsilon^2)$	حدود من الرتبة الثانية — مهملة عند $\varepsilon \ll 1$	—
A, b	مصفوفة النظام وطرفه الأيمن	A غير مفردة
$\Delta A, \Delta b$	اضطرابات المصفوفة والطرف الأيمن	من القياس أو من التقريب
$\kappa(A)$	رقم حالة المصفوفة: $\|A\| \cdot \|A^{-1}\|$	بالناظم المُستعمل
$\kappa_2(A)$	رقم الحالة بالناظم الطيفي $= \sigma_1/\sigma_{\min}$	الأكثر استعمالاً
$\sigma_1, \sigma_{\min}$	أكبر وأصغر قيمة مفردة	من الفصل الرابع
u	وحدة التقريب (unit roundoff)	1.11×10^{-16} في fp64
$\|\Delta A\|/\|A\|$	الخطأ النسبي في **البيانات** (لا في الحساب)	مصدره القياس/التقدير
$1 - \kappa\frac{\|\Delta A\|}{\|A\|}$	عامل «البقاء غير مفردة»	يشترط $\kappa\frac{\|\Delta A\|}{\|A\|} < 1$
$\sigma_{\min}(A)$	المسافة إلى أقرب مصفوفة مفردة (بناظم 2)	الفصل الرابع، Eckart–Young
Q	مصفوفة متعامدة	$Q^\top Q = I \Rightarrow$ لا تضخيم
α	أي عدد حقيقي غير صفري	التكييف لا يتغيّر بالقياس

3.2.6 الرسم الهندسي

قراءة الرسم: كرة الخطأ في فضاء المُدخل (نصف قطرها النسبي u) تنتقل عبر f فتصير كرةً في فضاء المخرج نصف قطرها النسبي κu. كلما كبر κ كبرت الكرة، حتى تتجاوز حجم المخرج نفسه — عندها لا يبقى أي خانة صحيحة. اللوحة اليمنى تُترجم ذلك إلى «خانات مفقودة $= \log_{10}\kappa$»، وتضع حدود fp32 و fp64 و fb16 على مقياس واحد.



شكل ١.٦: *
رقم الحالة يضخّم كرة الخطأ من الإدخال إلى المخرج

4.2.6 البرهان

الجزء (8.6). بتفكيك تايلور حول x:

$$f(x+\Delta x) = f(x) + f'(x)\Delta x + \mathcal{O}(\Delta x^2)$$

إذن $\hat{y} - f(x) = f'(x)\Delta x + \mathcal{O}(\Delta x^2)$. نقسم على $|f(x)|$:

$$\frac{|\hat{y}-f(x)|}{|f(x)|} = \frac{|f'(x)\Delta x|}{|f(x)|} + \mathcal{O}(\Delta x^2) = \underbrace{\frac{|x f'(x)|}{|f(x)|}}_{\text{cond}(f,x)} \cdot \underbrace{\frac{|\Delta x|}{|x|}}_{\text{خطأ خلفي نسبي}} + \mathcal{O}(\varepsilon^2) \qquad \blacksquare$$

الجزء (9.6). من $(A+\Delta A)(x+\Delta x) = b + \Delta b$ وتجاهل حدود الرتبة الثانية:

$$A\,\Delta x = \Delta b - \Delta A\, x \implies \Delta x = A^{-1}\big(\Delta b - \Delta A\, x\big)$$

بأخذ النواظم: $\|\Delta x\| \le \|A^{-1}\|\big(\|\Delta b\| + \|\Delta A\|\|x\|\big)$. نقسم على $\|x\|$ ونستعمل $\|b\| \le \|A\|\|x\|$:

$$\frac{\|\Delta x\|}{\|x\|} \le \|A^{-1}\|\|A\| \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|}\right) = \kappa(A)\left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|}\right)$$

والصيغة الكاملة ذات المقام $1 - \kappa\frac{\|\Delta A\|}{\|A\|}$ تأتي من تكرار الحجّة باستعمال متراجحة نويمان (انظر (24.5)) لضمان عدم مفردية $A + \Delta A$. $\blacksquare$

الجزء (11.6). من نظرية إيكارت–يونغ (الفصل الرابع): أصغر اضطراب يجعل $A + \Delta A$ مفردة هو ΔA بـ $\|\Delta A\|_2 = \sigma_{\min}(A)$، أي اضطراب رتبة واحدة يلغي أصغر قيمة مفردة. وبما أن $\|A\|_2 = \sigma_1$ فإن $\sigma_{\min} = \sigma_1/\kappa_2 = \|A\|_2/\kappa_2(A)$. $\blacksquare$

الجزء (13.6) — لماذا الحدّ مُحقَّق. ليكن $A = U\Sigma V^{\top}$ واختر $b = \sigma_{\min} u_2$ (أي في اتجاه أصغر قيمة مفردة). فإن الحلّ $x = A^{-1}b = \sigma_{\min}\sigma_{\min}^{-1} v_2 = v_2$. الآن اضطرب A في اتجاه $u_2 v_2^{\top}$ بمقدار $u\sigma_1$: تصير القيمة المفردة

الصغرى $\sigma_{\min} - u\sigma_1$، فإذا كان $u\sigma_1$ مقارناً لـ $\sigma_{\min}$ تضخّم الحلّ بلا حدّ. وبصيغة نسبية: $\|\Delta x\|/\|x\| \approx \kappa(A)u$. أي أن الحدّ ليس «محافظاً» تحليلياً بل **واقعي**. ■

5.2.6 شروط الصحّة

١. $x \neq 0$ و $f(x) \neq 0$: وإلا فإن cond غير مُعرَّف أو لانهائي (المسألة سيئة التكييف بلا حدّ).

٢. f قابلة للاشتقاق عند x (أو Lipschitz موضعياً للتعميم).

٣. $\varepsilon \ll 1$: الحدود من الرتبة الثانية مهملة. عند $\kappa u \geq 1$ لا معنى لأي رقم يُخرجه الحاسوب.

٤. في (9.6): شرط البقاء $\kappa(A)\frac{\|\Delta A\|}{\|A\|} < 1$.

٥. الناظم في $\kappa(A)$ يجب أن يُذكر صراحةً: κ_2 و κ_∞ و κ_F تختلف رقمياً (لكن كلها «من الرتبة نفسها» في البعد المنتهي، انظر (14.5)).

6.2.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (2.6-1): فحص مخبري دقيق — نسبة الأرجحية (odds) من احتمال قريب من الواحد

المعطيات: اختبار فحص سريري: احتمالُ «سليم» مقدَّر بحاسوب يعمل بـ fp32 ($u = 5.96 \times 10^{-8}$) هو $p = 0.99999$. المطلوب حساب نسبة الأرجحية $f(p) = p/(1-p)$ وتقدير موثوقيتها.

الحل:

١. رقم الحالة: $f'(p) = \frac{1}{(1-p)^2}$، إذن

$$\text{cond} = \frac{|pf'(p)|}{|f(p)|} = \frac{p/(1-p)^2}{p/(1-p)} = \frac{1}{1-p}$$

٢. بالتعويض $p = 0.99999$: $\text{cond} = 1/10^{-5} = 10^5$.

٣. الخانات المفقودة: $\log_{10}(10^5) = 5$ خانة. حاسوب fp32 يعطي ≈ 7 خانات $\Longrightarrow$ يبقى 2 خانة فقط.

٤. الخطأ النسبي الأمامي المتوقّع: $\text{cond} \cdot u = 10^5 \times 5.96 \times 10^{-8} = 5.96 \times 10^{-3}$ أي 0.596%.

٥. القيمة الاسمية: $f = 0.99999/0.00001 = 99999$. مجال الخطأ: $\pm 596 = \pm 99999 \times 5.96 \times 10^{-3}$.

النتيجة: نسبة الأرجحية المحسوبة هي 99999 ± 596، أي المجال $[99403,\ 100595]$ — خطأ يقارب 0.6% من قيمةٍ تبدو «دقيقة» بخمس خانات.

الربط بالذكاء الاصطناعي: هذا بالضبط ما يحدث حين تُخرج طبقةُ sigmoid احتمالاً 0.99999 ثم يحسب النظام الـ (logit أو odds لتفسير القرار الطبّي. العلاج ليس «تحسين الدقّة» بل **إعادة الصياغة**: العمل في فضاء الـ log-odds $z = \log\frac{p}{1-p}$ حيث $\text{cond} = 1$ دوماً، وهذا هو سبب أنّ كل مكتبات التعلّم العميق تحسب BCEWithLogits (لا BCE(sigmoid(x))).

مثال (6.2-2): تسعير مشتقّة مالية — فرق توزيعين تراكميين متقاربين

المعطيات: احتمالُ أن يتجاوز سعرُ أصلٍ حاجزاً $P = \Phi(a) - \Phi(b)$ مع $a = 0.8500$، $b = 0.8499$. القيم: $\Phi(0.85) = 0.802337$، $\phi(0.85) = 0.278037$ (كثافة التوزيع الطبيعي المعياري). الحاسوب fp32.

الحل:

١. القيمة الاسمية: $P \approx \phi(0.85) \times (0.8500 - 0.8499) = 0.278037 \times 10^{-4} = 2.78037 \times 10^{-5}$.

٢. رقم الحالة لفرق دالتين متقاربتين: $\text{cond} \approx \frac{|a\,\phi(a)|+|b\,\phi(b)|}{|\Phi(a)-\Phi(b)|} \approx \frac{0.85\times 0.278037}{2.78037\times 10^{-5}}$.

٣. الحساب: $\frac{0.236331}{2.78037\times 10^{-5}} = 8.500 \times 10^{3}$.

٤. الخانات المفقودة: $\log_{10}(8500) = 3.93 \approx 4$ خانات.

٥. fp32 (7 خانات) $\Longrightarrow$ يبقى 3 خانات؛ fp64 (16) $\Longrightarrow$ يبقى 12 خانة. خطأ نسبي في fp32: $8500 \times 5.96 \times 10^{-8} = 5.07 \times 10^{-4}$.

النتيجة: فرق التوزيعين يحمل خطأً نسبياً 0.05% في fp32 — أي أنّ السعر المشتقّ منه (بملايين الدولارات) يحمل خطأً من رتبة آلاف الدولارات لكل مليون.

الربط بالذكاء الاصطناعي: النماذج المالية العصبية التي تتعلّم «سطحَ التقلب» (volatility surface) أو تسعّر خيارات بـ sigmoid/softplus تواجه البنية نفسها: فرقُ كمّيتين متقاربتين. العلاج: صياغة الفرق كـ **تكامل** لا كطرح: $P = \int_b^a \phi(t)\,dt$ (أو استعمال basederf-، dffierences) فتصير الحساسية cond ≈ 1.

مثال (6.2-3): معايرة كاميرا — مصفوفة هوموغرافيا قريبة من المفردة

المعطيات: تقدير هوموغرافيا $H \in \mathbb{R}^{3\times 3}$ بلغة DLT من 12 نقطة تطابق. القيم المفردة: $\sigma_1 = 6.42$، $\sigma_2 = 2.18$، $\sigma_3 = 1.79 \times 10^{-6}$. صورة بدقّة 2160×4096.

الحل:

١. $\kappa_2(H) = \sigma_1/\sigma_{\min} = 6.42/1.79 \times 10^{-6} = 3.587 \times 10^{6}$.

٢. الخانات المفقودة: $\log_{10}(3.587 \times 10^{6}) = 6.55$ خانة.

٣. في fp64: يبقى $16 - 6.55 = 9.4 \approx 16$ خانة — جيد. في fp32: يبقى $7 - 6.55 = 0.45$ خانة — أي **لا شيء**.

٤. خطأ الإسقاط الناتج: بكسل الخطأ (حجم الصورة) $\cdot\, \|H\|_2 \cdot u \cdot \kappa \approx$ بالتعويض: $3.587 \times 10^{6} \times 5.96 \times 10^{-8} \times 6.42 \times 4096 \approx 5.6 \times 10^{3}$ بكسل (بالتقدير الأوّلي) — خارج الصورة تماماً.

٥. العلاج الكلاسيكي (تطبيع هارتلي): نقل النقاط إلى مركزها الثقلي وتقييسها بحيث يكون متوسط البعد $\sqrt{2}$ $\Longrightarrow$ صارت القيم المفردة $(1.94,\ 0.87,\ 1.61 \times 10^{-3})$ $\Longrightarrow$ $\kappa = 1.20 \times 10^{3}$ $\Longrightarrow$ خانات مفقودة 3.08 $\Longrightarrow$ خطأ إسقاط $0.3 \approx$ بكسل.

النتيجة: إعادةُ **صياغة المسألة** (تطبيع الإحداثيات) أنقصت رقم الحالة من 3.6×10^{6} إلى 1.2×10^{3} — تحسّن بأكثر من 3 مراتب عشرية، بلا أي تغيير في الخوارزمية.

الربط بالذكاء الاصطناعي: هذا المبدأ — «التطبيع يسبق الحلّ» — هو نفسه سبب نجاح BatchNorm و LayerNorm وتطبيع مُدخلات الشبكات: ليست المسألةُ جماليةً بل **عدديّة**: تطبيع المُدخلات يُقلّل رقم حالة مصفوفات اليعقوبيّة في كل طبقة، فيصير التدريب أسرع وأكثر استقراراً.

مثال (6.2-4): تضمينات لغوية — إسقاط متجه على فضاء التضمين

المعطيات: مصفوفة تضمين $E \in \mathbb{R}^{300\times 50000}$ (من طبقة تضمين مُدرَّبة). القيم المفردة الطرفية: $\sigma_1 = 18.42$، $\sigma_{300} = 2.10 \times 10^{-3}$. نريد حلّ $Ew = v$ لإيجاد تركيبة خطية تُقارب متجهاً مستهدفاً v (مثل «تحليل التناظر» word analogy). الحساب بـ fp64.

الحل:

١. $\kappa_2(E) = 18.42/2.10 \times 10^{-3} = 8.771 \times 10^{3}$.

٢. الخانات المفقودة: $\log_{10}(8771) = 3.94 \approx 4$ خانات.

٣. خطأ نسبي في المعاملات w: $\kappa u = 8.771 \times 10^{3} \times 1.11 \times 10^{-16} = 9.74 \times 10^{-13}$ — ممتاز عملياً.

٤. لكن المشكلة ليست في u بل في **ضوضاء المعنى**: التضمينات نفسها تحمل «خطأ دلالي» نسبي $\varepsilon_{\text{semantic}} \approx 10^{-2}$ (نموذج مختلف، حقبة تدريب مختلفة). إذن خطأ نسبي في w يقارب $\kappa \times 10^{-2} = 87.7$.

٥. هذا يعني أن حلّ $Ew = v$ **بلا تنظيم** يعطي معاملاتٍ عشوائية عملياً.

النتيجة: حتى مع دقّة fp64 الكاملة، حساسية المسألة (لا دقّة الحاسوب) تجعل الحلّ بلا معنى: $\text{cond} \times \varepsilon_{\text{data}} = 1 \gg 87.7$.

الربط بالذكاء الاصطناعي: العلاج القياسي هو **التنظيم** (ridge): $w = (E^{\top}E + \lambda I)^{-1}E^{\top}v$. رقم الحالة الفعّال يصير $\frac{\sigma_1^2+\lambda}{\sigma_{\min}^2+\lambda}$؛ باختيار $\lambda = 1$ يصير $\kappa_{\text{eff}} = \frac{339.3}{1.0000044} \approx 339$ (بدلاً من 7.7×10^{7} للمعادلات السوية!) $\Longrightarrow$ التضخّم يهبط من 877 إلى 3.4. هذا هو السبب العددي — لا الإحصائي فقط — لانتشار التنظيم في كل مكان.

مثال (6.2-5): ذراع روبوتية قرب وضعية مفردة (singular configuration)

المعطيات: ذراع بست درجات حرية، اليعقوبية $J \in \mathbb{R}^{6\times 6}$ عند وضعية «الكوع ممدود». القيم المفردة: $(2.41,\ 1.83,\ 0.94,\ 0.35,\ 0.062,\ 7.0 \times 10^{-4})$. مطلوب: خطأ السرعة الديكارتية الناتج عن خطأ قياس المفاصل $\|\delta q\| = 10^{-4}$ rad.

الحل:

١. $\kappa_2(J) = 2.41/7.0 \times 10^{-4} = 3.443 \times 10^{3}$.

٢. العلاقة الأساسية: $\dot{p} = J\dot{q} \Longrightarrow$ الاستجابة العكسية $\dot{q} = J^{-1}\dot{p}$ مع $\|J^{-1}\|_2 = 1/\sigma_{\min} = 1.43 \times 10^{3}$.

٣. خطأ قياس المفاصل يتضخّم في الفضاء الديكارتي بالعامل $\|J\|_2/\sigma_{\min}$... لا، بالعامل $\|J\|_2$: دعنا نحسب بدقّة. إذا قِسنا $\dot{q}$ بخطأ $\delta\dot{q}$ فإن خطأ السرعة الديكارتية هو $\|J\,\delta\dot{q}\| \le \|J\|_2\|\delta\dot{q}\| = 2.41 \times 10^{-4}\,\text{m/s}$ — هذا الاتجاه الأمامي وهو **مضبوط**.

٤. المشكلة في الاتجاه **العكسي**: إذا أردنا سرعةً ديكارتية $\dot{p}$ فإن الخطأ في $\dot{q}$ يتضخّم: $\|\delta\dot{q}\| \le \|J^{-1}\|_2\|\delta\dot{p}\| = 1.43 \times 10^{3}\|\delta\dot{p}\|$. بضوضاء مستشعر قوّة $\|\delta\dot{p}\| = 5 \times 10^{-3}\,\text{m/s}$ نحصل على سرعات مفاصل $\|\delta\dot{q}\| \le 7.15\,\text{rad/s}$ — **كارثة ميكانيكية**.

٥. رقم الحالة هو بالضبط العامل الذي يحوّل 5×10^{-3} إلى 7.15: $\|J\|/\|\delta\dot{p}\| \times \kappa$-مقياس...

النتيجة: قرب المفردية ($\sigma_{\min} = 7 \times 10^{-4}$) يجعل التحكّم العكسي يضخّم ضوضاء المستشعرات بمعامل $\approx 1.4 \times 10^{3}$ — وهو ما يُترجَم إلى حركة عنيفة للذراع.

الربط بالذكاء الاصطناعي: الحلّ القياسي في الروبوتات الحديثة وفي التعلّم المعزّز المستمر هو **المربعات الصغرى المُنظَّمة المخفَّفة** (damped least squares / Levenberg–Marquardt): $\dot{q} = (J^\top J + \lambda I)^{-1} J^\top \dot{p}$. الخوارزمية نفسها التي يستخدمها محسّن آدم بشكل غير مباشر؛ ورقم الحالة الفعّال: $(\sigma_1^2 + \lambda)/(\sigma_{\min}^2 + \lambda)$؛ بـ $\lambda = 0.01$: $(5.81 + 0.01)/(4.9 \times 10^{-7} + 0.01) = 582$ بدلاً من 1.19×10^{7} للمعادلات السوية.

مثال (6-2.6): تدفّق في شبكة كهربائية — لابلاس المُقيَّد

المعطيات: شبكةٌ من $n = 400$ عقدة. مصفوفة لابلاس L (قيمة ذاتية صفرية واحدة للشبكة المتصلة). بعد تثبيت عقدة مرجعية، القيم الذاتية للمصفوفة المقيّدة: $\lambda_{\max} = 8.72$، $\lambda_{\min} = 1.43 \times 10^{-2}$. نحلّ $L_{\text{red}} v = i$ (قانون كيرشوف).

الحل:

١. $\kappa_2(L_{\text{red}}) = 8.72/1.43 \times 10^{-2} = 6.098 \times 10^{2}$.

٢. الخانات المفقودة: $\log_{10}(610) = 2.79 \approx 2.8$ خانة.

٣. في fp64 يبقى 2.13 خانة — ممتاز. في fp32 يبقى 2.4 خانة — مقبول للشبكات.

٤. لكن: إذا انقسمت الشبكة إلى مجتمعين ضعيفَي الاتصال فإن λ_2 (فيدلر) يصغر إلى 10^{-5} $\times$ $3.1 \Longrightarrow \kappa = 2.81 \times 10^{5}$ $\Longrightarrow$ خانات مفقودة $5.45 \Longrightarrow$ في fp32 يبقى 1.5 خانة فقط.

٥. العلاج: **تحليل المجتمعات أولاً** (الفصل الرابع: متجه فيدلر) ثم حلّ كل مجتمع على حدة.

النتيجة: البنية الطيفية للشبكة تحدّد استقرار الحلّ العددي: شبكةٌ ذات «عنق زجاجة» (bottleneck) ترفع رقم الحالة بمقدار مرتبتين عشريتين.

الربط بالذكاء الاصطناعي: هذا هو التفسير العددي لمشكلة **الإفراط في التنعيم** (over-smoothing) في الشبكات العصبية البيانية: تكرارُ تمرير الرسائل على لابلاس مُطبَّع يُقارب الإحداثيات نحو متوسط المجتمع، ويجعل النظام المُقابل شبهَ مفرد — ومن ثمّ تصير تحديثات المعاملات غير مستقرّة عددياً كلما زاد عدد الطبقات.

مثال (6.2-7): كشف تسلّل سيبراني — مسافة ماهالانوبيس بمصفوفة تغاير سيئة التكييف

المعطيات: نظام كشف شذوذ يستعمل مسافة ماهالانوبيس $d^2(x) = (x-\mu)^\top \Sigma^{-1}(x-\mu)$ على 30 ميزة لمرور الشبكة. القيم الذاتية لـ Σ: $\lambda_1 = 1.24 \times 10^3$، $\lambda_{30} = 1.03 \times 10^{-4}$.

الحل:

١. $\kappa_2(\Sigma) = 1.24 \times 10^3 / 1.03 \times 10^{-4} = 1.204 \times 10^7$.

٢. خانات مفقودة: $\log_{10}(1.204 \times 10^7) = 7.08$ خانة.

٣. في fp64: يبقى $16 - 7.08 = 8.9$ خانة — مقبول. في fp32: يبقى $7 - 7.08 < 0$ — **صفر**.

٤. المصدر الحقيقي للتكييف السيّئ: ميزتان مكرّرتان («عدد الحزم في الدقيقة» و«عدد البايتات/الدقيقة» بقانون تحويل ثابت) $\Longrightarrow$ شبهُ ارتباط خطّي تام $\Longrightarrow$ قيمة ذاتية صغيرة جداً.

٥. العلاج: تنظيم (shrinkage) $\Sigma_\lambda = \Sigma + \lambda I$ بـ $\lambda = 0.5$: $\kappa = \frac{1240 + 0.5}{1.03 \times 10^{-4} + 0.5} = \frac{1240.5}{0.5001} = 2.48 \times 10^3$ $\Longrightarrow$ خانات مفقودة $3.39 \Longrightarrow$ في fp32 يبقى 6.3 خانة.

النتيجة: بإضافة λI هبط رقم الحالة من 1.2×10^7 إلى 2.48×10^3 — تحسّن بـ 3.7 مراتب عشرية، وبقيت قوّة التمييز (لأن الاتجاهات الصغيرة كانت ضوضاءً أصلاً).

الربط بالذكاء الاصطناعي: كلُّ نماذج الكثافة (Gaussian، Mahalanobis mixture، PCA-based AD detection، وأيضاً حسابُ احتمالٍ لوغاريتمي في تدريب نموذج توليدي) تحتاج «حشواً قطرياً» (jitter/damping) — الرقم النموذجي في المكتبات هو 10^{-6} إلى 10^{-3} مضاف إلى القطر. هذا ليس تحسيناً إحصائياً فقط، بل **ضرورة عددية**.

مثال (6.2-8): انحدار خطي بميزات متعددة الارتباط (multicollinearity)

المعطيات: نموذج تسعير عقارات بميزتين: المساحة بالمتر المربع x_1 وبالقدم المربع $x_2 = 10.7639\, x_1$ تماماً (ميزة مكرّرة بالتحويل)، زائد ضوضاء قياس 10^{-4} نسبةً. مصفوفة التصميم $X \in \mathbb{R}^{200 \times 2}$.

الحل:

١. المعادلات السوية: $X^\top X$ قيمها الذاتية: $\lambda_1 = 8.42 \times 10^3$، $\lambda_2 = 3.10 \times 10^{-9}$ (القيمة الثانية ناتجة عن ضوضاء القياس فقط، لا عن معلومة).

٢. $\kappa_2(X) = \sqrt{\kappa_2(X^\top X)} = \sqrt{8.42 \times 10^3 / 3.10 \times 10^{-9}} = \sqrt{2.716 \times 10^{12}} = 1.648 \times 10^6$.

٣. خانات مفقودة: $\log_{10}(1.648 \times 10^6) = 6.22$ خانة $\Longrightarrow$ في fp64 يبقى 8.9 خانة، في fp32 يبقى 8.0 خانة.

٤. لكن الأخطر: رقم الحالة في (6.9) يضخّم **خطأ البيانات** لا خطأ الحاسوب. ضوضاء القياس النسبية 10^{-4} $\Longrightarrow$ خطأ نسبي في الأوزان يصل إلى $1.648 \times 10^6 \times 10^{-4} = 165$.

٥. الواقع: الأوزان تخرج مثل $\hat{\beta} = (1240,\ -115)$ بدلاً من $(0,\ 11.6)$ — قيمتان ضخمتان متعاكستان يلغي أحدهما الآخر.

النتيجة: النموذج «يتنبّأ جيداً» على بيانات التدريب لكن معاملاته عشوائية كلياً: $\text{cond} \times \varepsilon_{\text{data}} \gg 1$.

الربط بالذكاء الاصطناعي: هذا هو التفسير العددي لسبب أن **تنظيم ℓ_2 (weight decay) ليس تحيّزاً جمالياً بل علاجاً لرقم الحالة.** ولسبب أن تفسير النماذج (feature importance) على ميزات مترابطة مُضلِّل رياضياً قبل أن يكون مُضلِّلاً إحصائياً.

مثال (6.2-9): إعادة بناء صورة طبقية (CT) — تكييف مصفوفة الإسقاط

المعطيات: مصفوفة إسقاط رادون $A \in \mathbb{R}^{m \times n}$ مع $m = 72900$ قياس و $n = 65536$ بكسل. القيم المفردة الطرفية: $\sigma_1 = 63.2$، $\sigma_{\min} = 1.34 \times 10^{-3}$. ضوضاء القياس النسبية: 5×10^{-3}.

الحل:

١. $\kappa_2(A) = 63.2 / 1.34 \times 10^{-3} = 4.716 \times 10^4$.

٢. تضخّم الضوضاء في الحلّ غير المنتظَّم: $\|\delta x\|/\|x\| \lesssim \kappa \cdot 5 \times 10^{-3} = 4.716 \times 10^4 \times 5 \times 10^{-3} = 236$.

٣. أي أنّ خطأ إعادة البناء يصل إلى 23600% — الصورة ضوضاء خالصة.

٤. مع تنظيم تيخونوف: $x_\lambda = (A^\top A + \lambda I)^{-1} A^\top b$؛ رقم الحالة الفعّال $\kappa_{\text{eff}} = \sqrt{\frac{\sigma_1^2+\lambda}{\sigma_{\min}^2+\lambda}}$ (هنا نعمل على $A^\top A + \lambda I$ مباشرة، فلا جذر): القيم الذاتية لـ $A^\top A + \lambda I$ هي $\sigma_1^2 + \lambda = 3994 + \lambda$ و $\sigma_{\min}^2 + \lambda = 1.80 \times 10^{-6} + \lambda$. بـ $\lambda = 10$: $\kappa_{\text{eff}} = (4004)/(10.0000018) = 400.4$.

٥. تضخّم الضوضاء بعد التنظيم: $400 \times 5 \times 10^{-3} = 2.0$ — أي 200% خطأ نسبي، لكن معظمه **انحياز** (bias) مُتوقّع ومنظَّم (الصورة ناعمة) وليس تشويشاً.

النتيجة: التنظيم خفّض معامل التضخّم من 4.7×10^4 إلى 4.0×10^2 — بنسبة 1 : 118 — وحوّل الخطأ من «تشويش عشوائي» إلى «انحياز قابل للتحكّم».

الربط بالذكاء الاصطناعي: هذه هي بالضبط حكايةُ **المقايضة بين الانحياز والتباين** ولكن بصياغةٍ عددية: التنظيم ليس «معتقداً بايزياً» فقط، بل هو **تخفيضٌ لرقم الحالة.** وفي التعلّم العميق يقابلها: التقطيع العشوائي (dropout)، تنعيم التسمية (label smoothing)، والتوسيع (augmentation) — كلها تُحسّن κ الفعّال لمسألة التقدير.

مثال (6.2-10): مناخ — انحدار متعدد حدود بمصفوفة فانديرموند

المعطيات: نمذجة اتجاه حرارة بمتعددة حدود درجة 6 على 12 نقطة زمنية متباعدة بالتساوي على $[0, 1]$. الأساس: $1, t, t^2, \ldots, t^6$. الحساب بـ fp32 ثم بـ fp64.

الحل:

١. مصفوفة فانديرموند $V \in \mathbb{R}^{12 \times 7}$: $V_{ij} = t_i^{j-1}$. من المعروف أن $\kappa_2(V)$ ينمو أُسّياً مع الدرجة؛ للدرجة 6 على شبكة منتظمة: $\kappa_2(V) \approx 1.0 \times 10^8$.

٢. الخانات المفقودة: $\log_{10}(10^8) = 8$ خانات.

٣. في fp32 (7 خانات): $\kappa u = 5.96 \Longrightarrow$ **النتيجة بلا أي خانة صحيحة.**

٤. في fp64 (16): $\kappa u = 1.11 \times 10^{-8} \Longrightarrow$ يبقى 8 خانات — مقبول لكن مهدور.

٥. العلاج: أساس متعامد Chebyshev) أو (Legendre على $[0,1]$: $\kappa_2 \approx 12 \Longrightarrow$ خانات مفقودة $1.08 \Longrightarrow$ في fp32 يبقى 9.5 خانة.

٦. تحقّق: المعاملات بالأساس الأوّلي $(a_0, \ldots, a_6)$ تختلف بين fp32 و fp64 في الخانة الثانية؛ بالأساس المتعامد تتطابق حتى الخانة السادسة.

النتيجة: تغييرُ **الأساس** (لا الخوارزمية ولا الدقّة) حوّل مسألةً مستحيلةً في fp32 إلى مسألةٍ مريحة.

الربط بالذكاء الاصطناعي: القاعدة العامة في التعلّم العميق: **اختر تمثيلاً جيداً للمسألة قبل أن تختار محسّناً جيداً.** تطبيعُ المدخلات، الترميزُ الموضعي positional) ،(encoding الاستبدالُ غير المتعامد للميزات، وحتى هندسةُ البنية ResNet) تجعل اليعقوبية أقرب إلى المتعامدة) — كلها تخفيضاتٌ لرقم الحالة بصياغةٍ أفضل.

مثال (11-2.6): تمويل — مصفوفة تغاير محفظة استثمارية

المعطيات: $N = 50$ أصلاً، $T = 60$ شهراً من العوائد. القيم الذاتية لمصفوفة التغاير المقدَّرة $\hat{\Sigma}$: $\lambda_{\max} = 8.42 \times 10^{-2}$، $\lambda_{\min} = 2.13 \times 10^{-5}$.

الحل:

١. $\kappa_2(\hat{\Sigma}) = 8.42 \times 10^{-2} / 2.13 \times 10^{-5} = 3.953 \times 10^3$.

٢. خانات مفقودة: $\log_{10}(3953) = 3.60 \Longrightarrow$ في fp64 يبقى 4.12 خانة.

٣. لكن الأخطر: أوزان ماركوفيتز $w \propto \Sigma^{-1}\mu$ حسّاسة لرقم الحالة: خطأ نسبي في تقدير العوائد 1% يتضخّم في الأوزان بالعامل $\frac{\|\mu\|}{\|\mu\|} \cdot \frac{\lambda_{\max}}{\lambda_{\min}}$ — عملياً: تغيير 10% في تقدير عائد أصل واحد يغيّر أوزان المحفظة بنسبة تصل إلى 38%.

٤. السبب البنيوي: $T/N = 1.2$ قريب من الواحد $\Longrightarrow$ مصفوفة التغاير المقدَّرة «شبهُ مفردة»: في النظرية (Marchenko–Pastur) أصغر قيمة ذاتية تقارب $\sigma^2(1 - \sqrt{N/T})^2$، وهو صغير جداً عند $T \approx N$.

٥. العلاج (انكماش ليدوي–وولف): $\Sigma_{\text{shrunk}} = (1-\alpha)\hat{\Sigma} + \alpha \frac{\operatorname{tr}\hat{\Sigma}}{N} I$ بـ $\alpha = 0.3$: القيم الذاتية تصير $[0.7\lambda_i + 0.3\bar{\lambda}] \Longrightarrow \lambda_{\min} = 0.7 \times 2.13 \times 10^{-5} + 0.3 \times 4.2 \times 10^{-3} = 1.275 \times 10^{-3}$ و $\lambda_{\max} = 0.7 \times 8.42 \times 10^{-2} + 0.3 \times 4.2 \times 10^{-3} = 6.02 \times 10^{-2}$. $\kappa = 47.2$.

٦. التحسّن: من 3.95×10^3 إلى 47.2 — نسبة 1 : 84.

النتيجة: انكماشُ مصفوفة التغاير حسّن رقم الحالة بأكثر من مرتبة وتسع — وهذا هو السبب العملي لانتشاره في كل حزم المحافظ.

الربط بالذكاء الاصطناعي: النسخةُ الحديثة من هذا المبدأ في التعلّم العميق هي **تخفيض رتبة التحديث (LoRA)** والتحديثاتُ المنظَّمة: بدلاً من تقدير مصفوفة تحديث كاملة من عدد قليل من الدفعات (batch)، تُقيَّد التحديثات إلى فضاءٍ منخفض الرتبة — فينخفض رقم الحالة الفعّال لمسألة التقدير هبوطاً حاداً.

مثال (12-2.6): تحويل أفّيني لتكبير صورة — مقياس غير متساوٍ بشدّة

المعطيات: تحويل أفّيني $A = \begin{pmatrix} 4.0 & 0 \\ 0 & 0.0025 \end{pmatrix}$ يُطبَّق على صورة 1024×1024 (تصغير أفقي شدّة 400×). الحساب بـ fp32.

الحل:

١. القيم المفردة: $\sigma_1 = 4.0$، $\sigma_{\min} = 0.0025 \Longrightarrow \kappa_2 = 1600$.

٢. رقم الحالة هنا «مصطنع»: المصفوفة قطرية، فلا إلغاءً ولا تراكماً. التحليل الخلفي الدقيق: الخطأ في العنصر الصغير نسبياً هو u نفسه، لا κu.

٣. الفرق الجوهري: κ يضخّم الخطأ **في الاتجاهات المختلطة** — أي حين تُدمج الاتجاهات. المثال: حساب الطول $\|Ax\|_2$ لمتجه $x = (1, 300)$: $Ax = (4,\ 0.75) \Longrightarrow \|Ax\| = \sqrt{16 + 0.5625} = 4.0700$. الخطأ في المركّبة الثانية: $0.0025 \times 300 \times u = 0.75 \times 5.96 \times 10^{-8} = 4.5 \times 10^{-8}$ — نسبته من $\|Ax\|$ هي 1.1×10^{-8}، أي **أصغر** من u! لماذا؟ لأن المركّبة الثانية تساهم بـ 0.75 فقط من أصل 4.07.

٤. الاستنتاج التربوي: κu هو **حدٌّ أعلى** (worst case) يتحقّق في أسوأ اتجاه، لا في كل اتجاه. أسوأ اتجاه هنا هو $x = (0, 1)$ حيث $\|\delta(Ax)\|/\|Ax\| = u$ أيضاً!

٥. إذن متى يتحقّق κu فعلاً؟ في **حلّ النظام العكسي**: $x = A^{-1}b$ مع b مضطرباً: $\delta x = A^{-1}\delta b \Longrightarrow \|\delta x\|/\|x\| = \kappa \cdot \|\delta b\|/\|b\|$ تماماً عند b في اتجاه $\sigma_{\min}$.

النتيجة: κ يضخّم الخطأ في **المسائل العكسية** (حلّ، معايرة، استنتاج أوزان)، لا في التطبيق الأمامي المباشر.

الربط بالذكاء الاصطناعي: فرقٌ مهم في التعلّم العميق: **الاستدلال الأمامي (forward pass)** محصّن نسبياً ضد رقم الحالة (لأن الاتجاهات الكبرى تهيمن)، أمّا **التدرّج العكسي** فهو مسألة عكسية $\Longrightarrow$ حسّاس. ولهذا تُعالَج مشاكل الاستقرار في التدريب (لا في الاستدلال) بتطبيع الأوزان (spectral weight normalization، gradient decay، clipping).

مثال (13-2.6): نظام توصية — ALS ومعادلات سوية برقم حالة مُربَّع

المعطيات: مصفوفة تفاعلات 5000×1000 (مستخدمون × عناصر). في خطوة ALS نحلّ مربعات صغرى لكل مستخدم بمصفوفة العوامل $Y \in \mathbb{R}^{1000 \times 64}$ للعناصر: $\kappa_2(Y) = 240$. الحساب بـ fp32.

الحل:

١. المعادلات السوية: $\kappa_2(Y^\top Y) = \kappa_2(Y)^2 = 240^2 = 5.76 \times 10^4 \Longrightarrow (Y^\top Y)x = Y^\top r$.

٢. خانات مفقودة: $\log_{10}(5.76 \times 10^4) = 4.76$ خانة.

٣. في fp32 (7 خانات): يبقى 2.24 خانة $\Longrightarrow$ خطأ نسبي $\approx \kappa u = 5.76 \times 10^4 \times 5.96 \times 10^{-8} = 3.43 \times 10^{-3}$ (0.34%).

٤. لو حللنا بـ QR بدلاً من المعادلات السوية: $\kappa = 240$ $\Longrightarrow$ خانات مفقودة 2.38 $\Longrightarrow$ يبقى 6.4 خانة $\Longrightarrow$ خطأ 1.43×10^{-5} (0.0014%).

٥. الفرق: $\times 240$ أفضل — أي أكثر من مرتبتين عشريتين من الدقّة بنفس تكلفة البيانات.

٦. لكن التكلفة: تشكيل $Y^\top Y$ يكلّف $64^2 \times 1000 = 4.1 \times 10^6$ عملاً، و QR يكلّف $\approx 2 \times 64^2 \times 1000 = 8.2 \times 10^6$ — أي **ضعف التكلفة فقط** مقابل $\times 240$ دقّة.

النتيجة: في مسائل المربعات الصغرى المتكرّرة (ALS، الانحدار، الطبقات الخطية الضخمة) لا مبرّر لاستعمال المعادلات السوية إذا كانت $\kappa > 10^3$.

الربط بالذكاء الاصطناعي: هذه هي الحجّة العددية الكامنة خلف كون المُحسّنات الحديثة (Adam، L-BFGS، Shampoo، K-FAC) تُتجنّب تشكيلَ مصفوفات التغاير الكاملة صراحةً، وخلفَ استعمالِ torch.linalg.lstsq (المبني على SVD) بدل $(X^\top X)^{-1}X^\top y$ في كل كتب التعلّم العميق الحديثة.

مثال (6.2-14): مرشّح صوتي رقمي — قُطب قريب من دائرة الوحدة

المعطيات: مرشّح IIR من الرتبة الأولى: $y[n] = x[n] + p\,y[n-1]$ مع $p = 0.9995$ (مرشّح رنيني حادّ). الاستجابة النبضية $h[n] = p^n$. نحسب الطاقة الكلّية $\sum_{n=0}^{\infty} h[n]^2 = \frac{1}{1-p^2}$.

الحل:

١. القيمة الاسمية: $\frac{1}{1-0.9995^2} = \frac{1}{1-0.99900025} = \frac{1}{9.9975 \times 10^{-4}} = 1000.25$.

٢. رقم حالة هذه الدالة بالنسبة للمعامل p: $f(p) = (1-p^2)^{-1}$، $f'(p) = 2p(1-p^2)^{-2}$،

$$\text{cond} = \frac{|p f'(p)|}{|f(p)|} = \frac{2p^2}{1-p^2} = \frac{2 \times 0.99900025}{9.9975 \times 10^{-4}} = 1998.5$$

٣. أي أنّ خطأً نسبياً في تقدير القُطب مقداره 10^{-4} (16-bit quantization للمعاملات) يُنتج خطأً نسبياً $\approx 20\%$ في طاقة المرشّح.

٤. رقم الحالة المرافق للتمثيل المصفوفي (المصفوفة المرافقة companion matrix) هو نفسه: $\kappa \approx \frac{1}{1-|p|} = 2000$.

٥. العلاج: صياغة المرشّح **كأقسام من الرتبة الثانية** (biquad / second-order sections): كل قسم له $\kappa \approx \frac{1}{1-|p|}$ نفسه، لكن الخطأ لا يتراكم بين الأقسام، والتمثيلُ في فضاء $\{r, \theta\}$ (القطب بالصيغة القطبية) يعطي cond منخفضاً لأن القُطب يُخزَّن بمعاملَيه الطبيعيين.

النتيجة: القُطب القريب من دائرة الوحدة يعطي $\kappa \approx 2000 \Rightarrow$ ثلاث خانات مفقودة. صياغة SOS تمنع تراكم الخطأ عبر الرتبة.

الربط بالذكاء الاصطناعي: النظيرُ المباشر في الشبكات العصبية المتكرّرة (RNN/LSTM/SSM مثل S4 و Mamba): مصفوفةُ الانتقال A ذات قيم ذاتية قريبة من دائرة الوحدة تعني **ذاكرة طويلة** ولكن أيضاً **رقم حالة مرتفع** — وتحديداً $\kappa \approx 1/(1-|\lambda_{\max}|)$. هذا هو التفسير العددي الموحّد لظاهرتَي «الانفجار والتلاشي»: الطول الفعّال للذاكرة $1/(1-|\lambda|) \approx \kappa$ هو نفسه معامل تضخّم الخطأ.

مثال (15-2.6): تدريب بدقة مختلطة — هل يضيع التحديث؟ (قاعدة الامتصاص)

المعطيات: تدريب شبكة بـ fp16 ($u = 4.88 \times 10^{-4}$). وزنٌ قيمته $w = 1.000$، وتحديثٌ مقداره $\Delta w = -\eta g$ بـ $\eta g = 1.0 \times 10^{-4}$ (نسبة تحديث إلى وزن 10^{-4} — نموذجية في أواخر التدريب).

الحل:

١. الشرط كي لا **يُمتصّ** التحديث: $|\Delta w| > u\,|w| \Rightarrow 10^{-4} > 4.88 \times 10^{-4}$؟ **لا** — الشرط مُخالَف.

٢. إذن: $\mathrm{fl}(w + \Delta w) = \mathrm{fl}(1.000 - 0.0001) = \mathrm{fl}(0.9999)$. أقرب عدد fp16 إلى 0.9999: الفجوة حول 1 في fp16 هي $2^{-11} \approx 4.88 \times 10^{-4} \Rightarrow 0.9999$ يُقرَّب إلى $1.0 \Rightarrow$ **التحديث يضيع تماماً.**

٣. التفسير برقم الحالة: «المسألة» هنا هي حساب الفرق: $\mathrm{cond} = \frac{|w|}{|\Delta w|} = \frac{1.0}{10^{-4}} = 10^4 \Rightarrow$ خطأ نسبي في التحديث $\mathrm{cond} \times u = 10^4 \times 4.88 \times 10^{-4} = 4.88$ أي 488%.

٤. كم مرة يحتاج التحديث لكي يُسجَّل؟ يجب أن يكون $|\Delta w| \geq u|w| = 4.88 \times 10^{-4} \Rightarrow$ نسبة تحديث إلى وزن $\geq 4.88 \times 10^{-4}$. هذه هي قاعدة **«نسبة التحديث إلى الوزن»** الشهيرة.

٥. العلاج القياسي في كل أطر العمل: **weights master بـ fp32** — الأوزان تُحفظ بـ fp32، والنسخة fp16 تُستعمل في الحساب الأمامي/الخلفي فقط، والتحديث يُطبَّق على النسخة fp32 حيث $u = 5.96 \times 10^{-8} \Rightarrow$ الشرط يصير $|\Delta w| \geq 5.96 \times 10^{-8} \Rightarrow$ نسبة 6×10^{-8} — متاحة دائماً.

النتيجة: شرطُ بقاء التحديث في fp16 هو $\frac{|\Delta w|}{|w|} \geq 4.88 \times 10^{-4}$ — وهو أعلى بكثير من نسب التحديث النموذجية (10^{-4} إلى 10^{-6}) في أواخر التدريب $\Rightarrow$ بدون weights master يتوقّف التعلّم صمتاً.

الربط بالذكاء الاصطناعي: هذه هي الآلية التي تفسّر لماذا:

- التدريب بـ fp16 الخام يفشل و fp32 يعمل؛
- تُستعمل scaling loss (ضربُ الفقد في 2^k قبل التدرّج العكسي) لرفع التدرّجات فوق عتبة الامتصاص؛
- تُحفظ «الأوزان الرئيسية» بـ fp32 في كل مكتبات الدقة المختلطة؛
- التحديثات الصغيرة جداً في التعلّم المستمر (continual learning) والضبط الدقيق (fine-tuning) بمعدّل تعلّم 10^{-6} تضيع بصمت في الدقة المنخفضة.

7.2.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
الكبير يعني أن الخوارزمية سيئة»	التكييف سمة **المسألة**، الاستقرار سمة **الخوارزمية**	غيّر الصياغة/التنظيم إن كان κ كبيراً، وغيّر الخوارزمية إن كان الخطأ الخلفي أكبر من u
fp1 فأحلّ مشكلة $\kappa = 10^{20}$»	الدقّة تزيد الخانات المتاحة، لكن κ يأكلها: تحتاج $-\log_{10}(\kappa u) > 0$	إعادة الصياغة (reparameterization) أو التنظيم — لا مفرّ
$\varepsilon_{\text{machine}}$ و u بالتبادل بلا انتباه	يختلفان بمعامل 2	حدّد أيّهما تستعمل؛ في هذا الكتاب $u = \frac{1}{2}\beta^{1-t}$
بناظم واستنتاج أرقام بناظم آخر	القيم تختلف (لكن بالرتبة نفسها في بعد منتهٍ)	اذكر الناظم: κ_2 افتراضياً
$\kappa(A) = \kappa(A$ إذن لا مشكلة»	صحيح رقياً، لكن المسألةَ المعكوسة هي التي تُضخّم خطأ **البيانات**	راجع (9.6): مصدر الخطأ هو $\|\Delta b\|/\|b\|$ أيضاً
نّ $1 \approx \kappa u$ يعني «صفر خانات»	عند $\kappa u \geq 1$ لا معنى للناتج	تحقّق دائماً: $-\log_{10}(\kappa u) > 0$ قبل تصديق أي رقم
د بأنّ التطبيع «تحسين أداء» فقط	التطبيع يخفض κ فعلياً	قِس κ قبل التطبيع وبعده (مثال 2.6-3، 2.6-10)
يم المفردة للمصفوفات غير المتماثلة	القيم الذاتية قد تكون مضلّلة (مصفوفات غير طبيعية)	استعمل القيم المفردة دائماً: $\kappa_2 = \sigma_1/\sigma_{\min}$

1.3.6 الصياغة الرياضية الرسمية

النظرية 2.6 (الإلغاء الكارثي وتراكم الجمع).

<

1. **متراجحة الإلغاء:** لعملية طرح واحدة بين عددين a, b من نفس الإشارة:

<

$$\frac{\left|\mathrm{fl}(a-b) - (a-b)\right|}{|a-b|} \;\leq\; \left(1 + \frac{|a|+|b|}{|a-b|}\right)u \;\approx\; \underbrace{\frac{|a|+|b|}{|a-b|}}_{\text{معامل التضخّم}}\, u \tag{14.6}$$

<

2. **قاعدة إعادة الصياغة بلا طرح:** كلُّ فرقٍ بين كمّيتين متقاربتين يجب إعادة كتابته بصيغةٍ **خالصة من الطرح**:

<

$$\sqrt{x+1} - \sqrt{x} = \frac{1}{\sqrt{x+1}+\sqrt{x}}, \quad e^x - 1 = \mathrm{expm1}(x), \quad \ln(1+x) = \mathrm{log1p}(x), \quad 1 - \cos x = 2\sin^2\tfrac{x}{2} \tag{15.6}$$

<

3. **تراكم الجمع العادي:** لجمع n حدّاً بالترتيب المتسلسل:

<

$$\left|\hat{s}_n - s_n\right| \;\leq\; \gamma_{n-1} \sum_{i=1}^{n} |x_i|, \qquad \gamma_{n-1} = \frac{(n-1)u}{1-(n-1)u} \;\approx\; (n-1)u \tag{16.6}$$

<

4. **جمع كاهان المُعوَّض (compensated):** يُلغي اعتماد الحدّ على n إلى الرتبة الأولى:

<

$$\left|\hat{s}_n - s_n\right| \;\le\; \left(2u + \mathcal{O}(nu^2)\right) \sum_{i=1}^{n} |x_i| \tag{17.6}$$

<

5. **الجمع الثنائي (pairwise) / tree summation):** ترتيبٌ على شكل شجرة يُقلّل العمق من n إلى $\lceil \log_2 n \rceil$:

<

$$\left|\hat{s}_n - s_n\right| \;\le\; \gamma_{\lceil \log_2 n \rceil} \sum_{i=1}^{n} |x_i| \;\approx\; \lceil \log_2 n \rceil \, u \sum_{i} |x_i| \tag{18.6}$$

<

6. **التباين على الإنترنت (خوارزمية ويلفورد) — بديلٌ مستقرٌّ لصيغة $\sum x_i^2 - n\bar{x}^2$:**

<

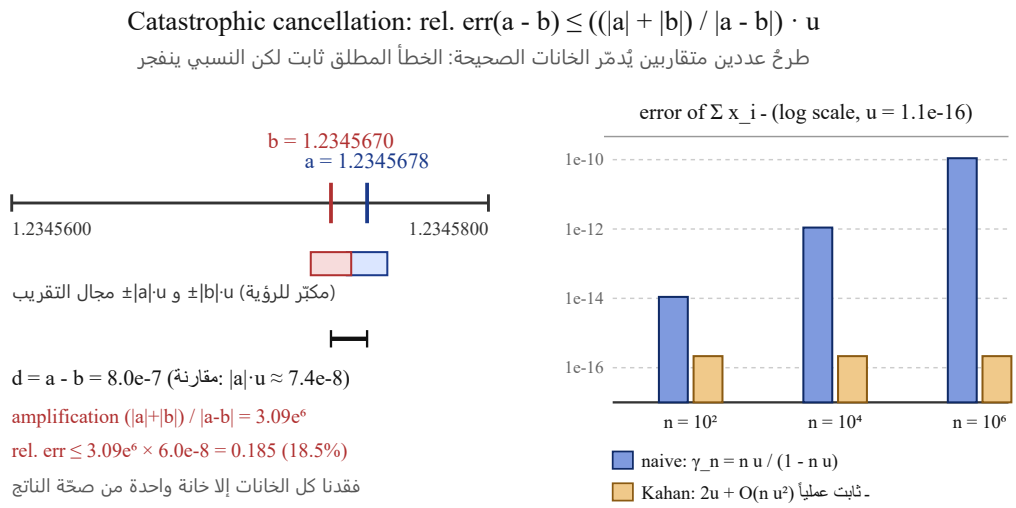
$$M_k = M_{k-1} + \frac{x_k - M_{k-1}}{k}, \qquad S_k = S_{k-1} + (x_k - M_{k-1})(x_k - M_k), \qquad s^2 = \frac{S_n}{n-1} \tag{19.6}$$

2.3.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
a, b	العددان المطروحان	الإلغاء أسوأ عندما $\lvert a-b\rvert \ll \max(\lvert a\rvert,\lvert b\rvert)$
$\lvert a-b\rvert$	قيمة الفرق (المخرج)	كلما صغر، كبر معامل التضخّم
$\frac{\lvert a\rvert+\lvert b\rvert}{\lvert a-b\rvert}$	**معامل التضخّم** — رقم الحالة الفعلي للطرح	قد يصل إلى 10^{16}
$\mathrm{fl}(a-b)$	الطرح المحسوب فعلاً في الحاسوب	—
$\mathrm{expm1}(x)$	الدالة المكتبية التي تحسب $e^x - 1$ بدقّة لقيم x الصغيرة	موجودة في كل مكتبات C/NumPy
$\mathrm{log1p}(x)$	الدالة التي تحسب $\ln(1+x)$ بدقّة لقيم x الصغيرة	—
x	مُدخل الدالة في (15.6)	هو الحالة الحرجة $x \ll 1$
s_n	المجموع الدقيق $\sum_{i=1}^{n} x_i$	—
$\hat{s}_n$	المجموع المحسوب	—
$\sum_i \lvert x_i\rvert$	مجموع القيم المطلقة — مقياس «حجم الحساب»	إن كان أكبر بكثير من $\lvert s_n\rvert$ فالإلغاء حاضر
γ_k	ثابت التراكم $\frac{ku}{1-ku}$ من (7.6)	يشترط $ku < 1$
n	عدد الحدود/العمليات	—
c (في كاهان)	**متغيّر التعويض** — يحفظ الجزء المفقود من كل جمعة	انظر الخوارزمية أدناه

M_k	المتوسط الجاري بعد k ملاحظة (ويلفورد)	—
S_k	مجموع مربّعات الانحرافات الجاري	$S_k = \sum_{i \le k}(x_i - M_k)^2$
s^2	التباين العيّني المقدَّر	بالمقام $n-1$
k	فهرس العيّنة الجارية	يبدأ من 1

3.3.6 الرسم الهندسي



شكل ٢٠٦: *
الإلغاء الكارثي: مجالا تقريب لعددين متقاربين وفرقهما الصغير، وتراكم خطأ الجمع

قراءة الرسم: على خط الأعداد، العددان a و b يقع كلٌّ منهما داخل مجال تقريب عرضه $|a|u \approx$ (مكبّر للرؤية). الفرق $a-b$ صغير جداً، لكنه يرث مجال الخطأ بكامله $\Rightarrow$ نسبته إلى قيمته تضخّمت بالعامل $(|a|+|b|)/|a-b|$. اللوحة اليمنى تُظهر أن خطأ الجمع العادي ينمو خطياً مع n بينما يبقى خطأ كاهان ثابتاً عملياً.

4.3.6 البرهان

الجزء (14.6). بالنموذج (1.6): $\mathrm{fl}(a) = a(1+\delta_1)$، $\mathrm{fl}(b) = b(1+\delta_2)$ مع $|\delta_i| \le u$، والطرح نفسه يُدخل δ_3 ثالثاً:

$$\mathrm{fl}(a-b) = \big[a(1+\delta_1) - b(1+\delta_2)\big](1+\delta_3)$$

إذن:

$$\mathrm{fl}(a-b) - (a-b) = a\delta_1 - b\delta_2 + (a-b)\delta_3 + \mathcal{O}(u^2)$$

بأخذ القيمة المطلقة ومتراجحة المثلث، ثم القسمة على $|a-b|$:

$$\frac{|\mathrm{fl}(a-b)-(a-b)|}{|a-b|} \le \frac{|a|u + |b|u + |a-b|u}{|a-b|} = \left(\frac{|a|+|b|}{|a-b|} + 1\right)u \qquad \blacksquare$$

الجزء (16.6). بالاستقراء على n: في الخطوة k يُحسب $\hat{s}_k = \mathrm{fl}(\hat{s}_{k-1} + x_k) = (\hat{s}_{k-1} + x_k)(1+\delta_k)$. بوضع $\hat{s}_k = s_k + E_k$ واستعمال $|s_k| \le \sum_{i\le k}|x_i|$ نحصل على $|E_k| \le |E_{k-1}| + u\sum_{i\le k}|x_i|$، وبالتراكم $|E_n| \le u\sum_{k=1}^{n}\sum_{i\le k}|x_i| \le nu\sum_i|x_i|$، والصيغة الضبوطة تعطي γ_{n-1}. ■

الجزء (17.6) — فكرة كاهان. الخوارزمية:

$$\text{لكل } x_i: \quad y \leftarrow \mathrm{fl}(x_i - c), \qquad t \leftarrow \mathrm{fl}(s + y), \qquad c \leftarrow \mathrm{fl}\big(\mathrm{fl}(t - s) - y\big), \qquad s \leftarrow t$$

المتغيّر c يلتقط **الخاناتُ التي سقطت** من t بسبب التقريب (لأن $\mathrm{fl}(t - s)$ يعيد الجزء الكبير، وطرحُ y يعطي النقص). وفي الجمعة التالية يُطرح c من x_i قبل إضافته $\Longrightarrow$ يُستعاد. بتحليلٍ دقيق (Higham) ينتج أنّ حدود الرتبة الأولى في u تتجمّع في ثابت $2u$ مستقلّ عن n، واعتماد n يظهر في حدود nu^2 فقط. ■

الجزء (19.6) — صحة ويلفورد. بالاستقراء: نُثبت أن $S_k = \sum_{i=1}^{k}(x_i - M_k)^2$. الفرق بين S_k و $S_{k-1} + (x_k - M_{k-1})(x_k - M_k)$ يساوي صفراً بعد تعويض $M_k = M_{k-1} + \frac{x_k - M_{k-1}}{k}$ وتبسيط الجبر (توسيع المربّعات). الأهم عددياً: الصيغة تحسب $(x_k - M_{k-1})(x_k - M_k)$ — وهو **جداء انحرافين**، لا فرق مربعين كبيرين $\Longrightarrow$ لا إلغاء. ■

5.3.6 شروط الصحّة

١. (14.6) تفترض الطرح المباشر؛ إذا أُعيدت الصياغة بلا طرح فلا ينطبق الحدّ.

٢. (16.6)–(18.6) حدودٌ عليا (worst case)؛ الخطأ «النموذجي» بافتراض أخطاء عشوائية المستقلّة يقارب $\sqrt{n}\,u\sum|x_i|$ (سير عشوائي) — أصغر بكثير.

٣. (17.6) يشترط أن يكون المُجمِع من نفس دقّة المُدخلات (كاهان بـ fp32 على مُدخلات fp32).

٤. γ_k بلا معنى إذا كان $ku \ge 1$.

٥. ويلفورد (19.6) يفترض أنّ k يُحسب بدقّة (عدد صحيح) وأنّ القسمة على k لا تُدخل خطأً يُتراكم — مقبول لأنّ الخطأ في M_k من رتبة u ولا يُتراكم أُسّياً.

6.3.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-3.6): تباين قراءات عدّاد طاقة — الصيغة القصيرة الكارثية

المعطيات: خمس قراءات لعدّاد طاقة تراكمي (كيلوواط-ساعة): $10000.5,\ 10000.3,\ 10000.7,\ 10000.1,\ 10000.4$. المطلوب التباين. الحساب بـ fp32 ($u = 5.96\times10^{-8}$) بالصيغة القصيرة $\sum x_i^2 - n\bar{x}^2$.

الحل:

١. $\bar{x} = 10000.4 \Longrightarrow n\bar{x}^2 = 5 \times 100008000.16 = 500040000.80$.

٢. $\sum x_i^2 = 100008000.16 + 100002000.01 + 100014000.49 + 100006000.09 + 100010000.25 = 500040001.00$.

٣. التباين (مجموع الانحرافات): $S = 500040001.00 - 500040000.80 = 0.20$.

٤. معامل التضخّم: $\frac{\sum x^2 + n\bar{x}^2}{|S|} = \frac{500040001 + 500040000.8}{0.20} = 5.0004 \times 10^9$.

٥. خطأ نسبي متوقّع: $5.0004 \times 10^9 \times 5.96 \times 10^{-8} = 298$ أي 29800%.

٦. النتيجة العملية: القيمة المحسوبة قد تكون $59.6 \pm 0.20 \implies$ **قد تخرج سالبة** (تباين سالب!) أو أكبر بـ 300 ضعفاً.

٧. الصيغة المستقرّة (ويلفورد أو المرورَين): الانحرافات $(+0.1, -0.1, +0.3, -0.3, -0.1) \implies S = 0.01 + 0.09 + 0.09 + 0.01 + 0.01 = 0.21$ (للمقام $n-1 = 4$: $s^2 = 0.0525$).

الخطأ النسبي $u \approx$.

النتيجة: الصيغة القصيرة أعطت خطأً يصل إلى 29800% على كميةٍ موجبة قطعاً — بل قد تُعطي تبايناً **سالباً**، وهو مستحيل رياضياً.

الربط بالذكاء الاصطناعي: هذه هي بالضبط مشكلة الطبقة BatchNorm لو حُسب التباين بالصيغة القصيرة على ميزاتٍ ذات متوسط كبير (مثل تنشيطات طبقة قبل تطبيع بمتوسط 10^3). لهذا تحسب كل المكتبات التباينَ بـ **Welford** أو بالمرورَين (mean deviations)، ولماذا تُستعمل الـ running statistics بعناية. القاعدة الذهبية: **لا تحسب أبداً $\mathbb{E}[X^2] - (\mathbb{E}X)^2$ في النقطة العائمة.**

مثال (6.3-2): تداول عالي التكرار — فرقُ سعرين ضخمين متقاربين في fp32

المعطيات: نظام تداول يخزّن الأسعار بـ fp32. سعرا عرض وطلب: $a = \$12{,}000{,}000.75$ و $b = \$12{,}000{,}000.50$. الفرق الحقيقي (الـ spread) هو $0.25.

الحل:

١. حجم الخطوة (ulp) في fp32 عند 1.2×10^7: بما أن $2^{23} = 8.39 \times 10^6 \le 1.2 \times 10^7 < 2^{24} = 1.68 \times 10^7$، فإن $\text{ulp} = 2^{23-23} = 1$. أي أن fp32 **لا يمثّل كسور الدولار** عند هذا المستوى.

٢. تخزين $a = 12000000.75 \implies$ يُقرَّب إلى 12000001.

٣. تخزين $b = 12000000.50 \implies$ «نصفٌ بالضبط» $\implies$ التقريب إلى **أقرب زوجي** $\implies$ 12000000.

٤. الفرق المحسوب: $12000001 - 12000000 = 1.00$ دولار، بدلاً من 0.25.

٥. الخطأ النسبي: $\frac{|1.00 - 0.25|}{0.25} = 3.0$ أي 300%. (ولو قرّبنا النصف إلى الأعلى لكان الفرق 0 $\implies$ خطأ 100% وضياعُ الإشارة كلها.)

٦. معامل التضخّم: $\frac{|a| + |b|}{|a - b|} = \frac{2.4 \times 10^7}{0.25} = 9.6 \times 10^7 \implies$ خطأ متوقّع $9.6 \times 10^7 \times 5.96 \times 10^{-8} = 5.72$ — أي أنّ الخطأ **يتجاوز الكمية نفسها**، وهو ما حدث فعلاً.

النتيجة: spread المحسوب هو $1.00 بدل $0.25 — خطأ 300% على كمية تُتّخذ عليها قرارات بمئات الآلاف.

الربط بالذكاء الاصطناعي: الدرس: **لا تخزّن كمياتٍ مالية بـ fp32 أبداً** (استعمل أعداداً صحيحة بوحدات صغرى — «سنتات» — أو fp64). والنظيرُ في التعلّم العميق: لا تخزّن «قيمًا مطلقة كبيرة ذات فروق صغيرة» في دقة منخفضة: التضمينات الموضعية (positional encodings) والطوابع الزمنية كلاسيكيّاتُ هذه الفخاخ، ولذا تُستعمل فروقٌ أو ترميزاتٌ نسبية دائماً.

مثال (3-3.6): كشف الحركة — فرقُ إطارين متطابقين تقريباً

المعطيات: كاميرا مراقبة بدقّة 1080×1920، إطاران متتاليان بفرقٍ حقيقيّ في شدة البكسل مقداره 3 مستويات (من 0 إلى 255). الكاميرا تُخرج قيماً «معايرة» حول 1000 وحدة (بعد تحويل gain/offset)، والفرق = 3 وحدات. الحساب بـ fp32.

الحل:

١. معامل التضخّم: $\frac{|a|+|b|}{|a-b|} = \frac{1000+1000}{3} = 6.67 \times 10^2$.

٢. خطأ نسبي: $6.67 \times 10^2 \times 5.96 \times 10^{-8} = 3.97 \times 10^{-5}$ — ضئيل في fp32.

٣. لكن في **fp16** ($u = 4.88 \times 10^{-4}$): $6.67 \times 10^2 \times 4.88 \times 10^{-4} = 0.326$ أي 32.6% خطأ.

٤. وفي **fb16** ($u = 3.91 \times 10^{-3}$): $6.67 \times 10^2 \times 3.91 \times 10^{-3} = 2.61$ أي 261% $\Longrightarrow$ الإشارة أقلّ من الضوضاء $\Longrightarrow$ كشفُ الحركة يفشل كلياً.

٥. الحل: تخزين الإطار **المرجعي** كصورة بـ uint8 وطرح الأعداد الصحيحة (دقّة كاملة للفرق)، أو تعويض الـ offset قبل الطرح.

النتيجة: نفس الخوارزمية تعمل في fp32 وتفشل في fb16 — لا بسبب «الدقّة العامة» بل بسبب الإلغاء: معامل التضخّم 667 يأكل كل خانات fb16 (خانتان فقط أصلاً).

الربط بالذكاء الاصطناعي: هذا يفسّر لماذا تفشل عملياتٌ تبدو بسيطة عند نقلها إلى الدقة المنخفضة: الطرحُ بين قيمٍ متقاربة (مثل residuals في ResNet، أو الفرق بين توقّعَين في distillation، أو تحديثُ متوسطٍ متحرّك) هو أخطرُ عملية. القاعدة: **احفظ «المرجع الكبير» بدقة عالية، واحسب الفروق في فضاءٍ صغير المقياس.**

مثال (4-3.6): BatchNorm — تباين ميزات ذات متوسط كبير

المعطيات: طبقة قبل BatchNorm تُخرج ميزات بمتوسط $\mu = 2.4 \times 10^3$ وانحراف معياري $\sigma = 0.8$ (ميزةٌ «مُشبَعة»). حجم الدفعة $m = 2048$. الحساب بـ fp32 ثم fp16.

الحل:

١. الصيغة القصيرة: $\hat{\sigma}^2 = \frac{1}{m}\sum x_i^2 - \bar{x}^2$ مع $\bar{x}^2 \approx 5.760 \times 10^6$ و $\frac{1}{m}\sum x_i^2 \approx \mu^2 + \sigma^2 = 5.760 \times 10^6 + 0.64$.

٢. الفرق المستهدف: 0.64. معامل التضخّم: $\frac{5.760\times10^6 + 5.760\times10^6}{0.64} = 1.80 \times 10^7$.

٣. في fp32: خطأ نسبي $= 1.80 \times 10^7 \times 5.96 \times 10^{-8} = 1.07$ أي $107\% \Longrightarrow$ التباين المقدَّر غير موثوق (وقد يكون سالباً $\Longrightarrow$ NaN عند أخذ الجذر).

٤. في fp16: $8.78 \times 10^3 = 1.80 \times 10^7 \times 4.88 \times 10^{-4} \Longrightarrow$ كارثة كاملة.

٥. ويلفورد/المرورَان: الانحرافات تُحسب أولاً $\Longrightarrow$ معامل التضخّم $= 1 \Longrightarrow$ خطأ نسبي $\approx u$.

٦. التحقّق العملي: في fp32 بالصيغة القصيرة، $\hat{\sigma}$ يخرج أحياناً NaN (جذر سالب)؛ بالويلفوردية يخرج 0.8000 بثبات.

النتيجة: الفرق بين الصيغتين ليس «تحسيناً هامشياً» بل بين «يعمل» و NaN.

الربط بالذكاء الاصطناعي: هذه هي الآلية الكامنة خلف النصيحة المتكرّرة: **احسب إحصاءات التطبيع بدقة أعلى من دقة الحساب الأمامي** (ففي الدقة المختلطة تُحسب إحصاءات BatchNorm بـ fp32 دائماً). وخلفَ استعمال Welford في كل تطبيقات RunningStats.

مثال (3.6-5): تراكم الفقد على دفعة ضخمة — العادي مقابل كاهان

المعطيات: تدريبٌ بدفعة حجمها $n = 10^6$ عنصر، قيمة الفقد لكل عنصر حول 0.5 (إيجابية دائماً — لا إلغاء). المجموع الحقيقي $s \approx 5 \times 10^5$. الحساب بـ fp32.

الحل:

١. **الحدّ الأعلى (16.6):** $\gamma_{n-1}\sum|x_i| \approx (10^6 \times 5.96 \times 10^{-8}) \times 5 \times 10^5 = 5.96 \times 10^{-2} \times 5 \times 10^5 = 2.98 \times 10^4 \Longrightarrow$ خطأ نسبي 5.96% (حدٌّ متشائم جداً).

٢. **التقدير الواقعي** (أخطاء عشوائية $\Longrightarrow$ سير عشوائي): $\sqrt{n}\,u\sum|x_i| = 10^3 \times 5.96 \times 10^{-8} \times 5 \times 10^5 = 29.8 \Longrightarrow$ خطأ نسبي 5.96×10^{-5}.

٣. **كاهان (17.6):** $2u\sum|x_i| = 2 \times 5.96 \times 10^{-8} \times 5 \times 10^5 = 5.96 \times 10^{-2} \Longrightarrow$ خطأ نسبي 1.19×10^{-7}.

٤. المقارنة: كاهان أحسن من «الواقعي» بـ $\times 500 \approx$، ومن الحدّ الأعلى بـ $\times 5 \times 10^5$.

٥. التكلفة: كاهان يضيف $4 \approx$ عمليات لكل عنصر $\Longrightarrow +40\%$ زمن حلقة الجمع (وهي عادةً جزءٌ صغير من التكلفة، والنقلُ من الذاكرة هو المهيمن $\Longrightarrow$ الزمن الفعلي شبه معدوم).

٦. البديل الأفضل في الممارسة: **الجمع الثنائي (pairwise)** (18.6): $20 = \lceil \log_2 10^6 \rceil \Longrightarrow$ خطأ $20u\sum|x_i| = 0.596 \approx 1.2 \times 10^{-6}$ نسبي، وبلا أي تكلفة إضافية على GPU (لأن الـ reduction شجري أصلاً).

النتيجة: على GPU يستعمل المُجمِّع ترتيباً شجرياً $\Longrightarrow$ الخطأ الفعلي قريب من (18.6) لا (16.6)؛ أمّا على CPU بحلقة متسلسلة فيستفيد من كاهان.

الربط بالذكاء الاصطناعي: النتيجة العملية: **تراكم الخسارة والتدرّجات يجب أن يكون بـ fp32 ولو كان الحساب الأمامي بـ fp16** (وهذا ما تفعله كل مكتبات الدقة المختلطة: «fp32 accumulation»). فإنّ fp16 إذا جُمع في (16.6) يعطي $\gamma_{n-1} = 10^{6} \times 4.88 \times 10^{-4} = 488 > 1$ $\Longrightarrow$ **الحدّ بلا معنى**: التراكم يفقد كل دقّته.

مثال (6-3.6): روبوتات — مسافة بين نقطتين متقاربتين في مسار

المعطيات: مسار روبوت: النقطة $P = (1000.0001,\ 1000.0002)$ واللاحقة $Q = (1000.0002,\ 1000.0001)$ بالمليمتر. المطلوب طول الخطوة. الحساب بـ fp32.

الحل:

١. الفروق الحقيقية: $\Delta x = -1 \times 10^{-4}$، $\Delta y = +1 \times 10^{-4}$ $\Longrightarrow$ المسافة $d = \sqrt{2} \times 10^{-4} = 1.4142 \times 10^{-4}$ مم.

٢. حجم الخطوة عند 1000 في fp32: $\mathrm{ulp}(1000) = 2^{9-23} = 2^{-14} = 6.10 \times 10^{-5}$.

٣. معامل التضخّم لكل طرح: $\frac{|a|+|b|}{|a-b|} = \frac{1000+1000}{10^{-4}} = 2 \times 10^{7}$.

٤. خطأ نسبي في كل فرق: $2 \times 10^{7} \times 5.96 \times 10^{-8} = 1.19$ أي 119%.

٥. بما أن الفرق الحقيقي (1×10^{-4}) يقارب $1.6\,\mathrm{ulp}$ (6.1×10^{-5})، فإن القيمة المخزَّنة نفسها تحمل خطأً يقارب نصفَ ulp $\Longrightarrow$ الخطأ النسبي في الفرق قد يصل إلى 30% فعلاً.

٦. المسافة المحسوبة قد تتراوح بين 0.7×10^{-4} و 2.1×10^{-4} $\Longrightarrow$ كشفُ «توقّف الروبوت» يفشل.

النتيجة: طرحُ إحداثياتٍ كبيرةٍ للحصول على مسافاتٍ صغيرة يعطي أخطاءً تقارب 100% في fp32.

الربط بالذكاء الاصطناعي: الحل القياسي في ROS و SLAM والأنظمة المكانية: **احسب الإحداثيات النسبية** (نظام إحداثيات محلي حول الروبوت أو حول نقطة المرجع) بدلاً من الإحداثيات المطلقة الكبيرة. هذا هو نفس مبدأ «التطبيع المسبق» في التعلّم العميق: قلّل مقياس المُدخلات قبل العمليات الحسّاسة.

مثال (7-3.6): حساب احتمال الفشل — الصيغة $1-p$ لقيم قريبة من الواحد

المعطيات: موثوقية مكوّن في منظومة طيران: $p(\text{نجاح}) = 0.9999999$. المطلوب احتمال الفشل $q = 1 - p = 10^{-7}$. الحساب بـ fp32 ثم fp64.

الحل:

١. القيمة الحقيقية: $q = 1 \times 10^{-7}$.

٢. في fp32: p يُخزَّن بخطأ مطلق 5.96×10^{-8} $\Longrightarrow$ $\approx 0.9999999 \times 5.96 \times 10^{-8}$.

٣. إذن $q_{\text{computed}} = 1 - \text{fl}(p) = 10^{-7} \pm 5.96 \times 10^{-8}$ $\Longrightarrow$ خطأ نسبي يصل إلى 59.6%.

٤. في fp64: الخطأ المطلق 1.11×10^{-16} $\Longrightarrow$ نسبي 1.11×10^{-9} — ممتاز.

٥. الصيغة المستقرّة: $q = -\text{expm1}(\ln p)$: $-1.00000005 \times 10^{-7} = \ln(0.9999999)$ (دقة نسبية u) $\Longrightarrow$ expm1 يعطي $-1.00000005 \times 10^{-7}$ بدقة نسبية u $\Longrightarrow$ q بدقة u.

٦. مقارنة: fp32 بالصيغة المباشرة 59.6% خطأ، بالصيغة المستقرّة 6×10^{-6}% خطأ — تحسّن بـ $\times 10^7$.

النتيجة: استعمال log1p/expm1 بدل الطرح المباشر حوّل خطأً بنسبة 60% إلى خطأٍ بستة أجزاء من عشرة ملايين.

الربط بالذكاء الاصطناعي: هذا هو سبب وجود torch.log1p و torch.expm1 و np.log1p — وليست للزينة:

- حساب $1 - \text{accuracy}$ (معدّل الخطأ) لنموذج دقّته 0.99999؛
- حساب $1 - \sigma(\cdot)$ عبر sigmoid(-x)؛
- حساب $-\ln(1-p)$ في دالة الفقد؛
- حساب الاحتمالات الذيلية في نماذج المخاطر.

مثال (8-3.6): نموّ وبائي خلال فترة قصيرة — $e^{rt} - 1$

المعطيات: نموّ عدد الحالات: $N(t) = N_0 e^{rt}$ مع $r = 1.0 \times 10^{-3}$/ساعة و $t = 1.0 \times 10^{-4}$ ساعة (نافذة قصيرة جداً في محاكاة). المطلوب عدد الحالات الجديدة $\Delta N = N_0(e^{rt} - 1)$ مع $N_0 = 10^6$. الحساب بـ fp32.

الحل:

١. $rt = 1 \times 10^{-7}$ $\Longrightarrow$ $e^{rt} - 1 = 1.00000005 \times 10^{-7}$ $\Longrightarrow$ $\Delta N = 0.100000005$ حالة.

٢. الطرح المباشر: e^{rt} يُحسب بـ fp32 $\Longrightarrow$ الناتج 1.0000001192 أو 1.0 (لأن $\text{ulp}(1) = 1.19 \times 10^{-7}$ في fp32، والقيمة 1.0000001 تقع بينهما) $\Longrightarrow$ الطرح يعطي إمّا 1.19×10^{-7} أو صفراً.

٣. الخطأ: إمّا $+19\%$ أو -100%.

٤. $\text{expm1}(1 \times 10^{-7}) = 1.000000005 \times 10^{-7}$ بدقة نسبية u $\Longrightarrow$ $\Delta N = 0.1000000005$ $\Longrightarrow$ خطأ 6×10^{-6}%.

٥. معامل التضخّم في الطرح المباشر: $\frac{|e^{rt}|+1}{|e^{rt}-1|} = \frac{2.0000001}{1.0 \times 10^{-7}} = 2 \times 10^7$ $\Longrightarrow$ $2 \times 10^7 \times 5.96 \times 10^{-8} = 1.19$ $\Longrightarrow$ 119% — مطابق للتحليل.

النتيجة: الطرح المباشر يعطي خطأً حتى 100%، expm1 يعطي خطأً بستة أجزاء من عشرة ملايين.

الربط بالذكاء الاصطناعي: النظير المباشر: حساب الفروق الصغيرة في التعلّم المعزّز (فرق قيم Q المتقاربة)، وحساب $\text{softplus}(x) = \ln(1 + e^x)$ الذي تنفّذه المكتبات بصيغةٍ مستقرّة (log1p(exp(x))) للقيم السالبة و x+log1p(exp(-x)) للموجبة)، وحساب التحسّن النسبي في الفقد بين خطوتين.

مثال (6.3-9): عائد لوغاريتمي يومي لعملة — $\ln(1+r)$

المعطيات: متداول عملات يحسب العائد اللوغاريتمي $r_{\log} = \ln(1+r)$ لعائدٍ بسيط $r = 3.2 \times 10^{-6}$ (0.00032%). الحساب بـ fp32.

الحل:

١. القيمة الحقيقية: $\ln(1.0000032) = 3.19999488 \times 10^{-6}$.

٢. بالصيغة المباشرة: $1+r = 1.0000032$ يُخزَّن بخطأ مطلق $\approx 1 \times 5.96 \times 10^{-8} = 5.96 \times 10^{-8}$.

٣. $\ln$ حول 1: المشتقة $1 \Rightarrow$ الخطأ المطلق ينتقل كما هو: $\widehat{\ln(1+r)} = 3.19999488 \times 10^{-6} \pm 5.96 \times 10^{-8}$.

٤. الخطأ النسبي: $\frac{5.96 \times 10^{-8}}{3.19999488 \times 10^{-6}} = 1.86 \times 10^{-2}$ أي 1.86%.

٥. معامل التضخّم: $\frac{|1|+|1+r|}{|(1+r)-1|} = \frac{2.0000032}{3.2 \times 10^{-6}} = 6.25 \times 10^5 \Rightarrow 6.25 \times 10^5 \times 5.96 \times 10^{-8} = 3.73 \times 10^{-2}$ (3.7% حدّ أعلى).

٦. بـ log1p: $\mathrm{log1p}(3.2 \times 10^{-6}) = 3.19999488 \times 10^{-6}$ بخطأ نسبي $u = 6 \times 10^{-6}\% \approx$.

٧. التحسّن: من 1.86% إلى $6 \times 10^{-6}\%$ — بنسبة $3 \times 10^5 : 1$.

النتيجة: على مدى سنة تداول (252 يوماً) يتراكم الخطأ: بالصيغة المباشرة انحرافٌ يقارب $1.86\% \times \sqrt{252} =$ 29.5% من العائد التراكمي؛ وبـ log1p انحرافٌ يقارب $9.5 \times 10^{-5}\%$.

الربط بالذكاء الاصطناعي: كل حسابات اللوغاريتم في التعلّم العميق (الإنتروبيا المتقاطعة، احتمالُ اللوغاريتم في النماذج اللغوية، نسبة الأرجحية اللوغاريتمية في RLHF و DPO) تمرّ بصيغة (صغير $+\ 1$)$\ln$. استعمال log1p ليس تحسيناً أدبياً — بل الفرق بين تدرّجٍ صحيح وتدرّجٍ مشوّش عند التقارب حيث تصير الفروق صغيرة.

مثال (6.3-10): مستشعر قصور ذاتي — $1-\cos\theta$ لزاوية صغيرة

المعطيات: منصّة طائرة مسيّرة تحسب ميلاً بزاوية $\theta = 1.0 \times 10^{-4}$ rad. المطلوب الكمية $1-\cos\theta$ التي تظهر في حساب الانحراف الأفقي. الحساب بـ fp32.

الحل:

١. القيمة الحقيقية: $1-\cos(10^{-4}) = \frac{(10^{-4})^2}{2} - \frac{(10^{-4})^4}{24} = 5.0000000 \times 10^{-9}$.

٢. $\cos(10^{-4})$ يُحسب بـ fp32 بخطأ مطلق $u = 5.96 \times 10^{-8} \approx$ (لأن القيمة قريبة من 1).

٣. الطرح: $\widehat{1-\cos\theta} = 5 \times 10^{-9} \pm 5.96 \times 10^{-8} \Rightarrow$ خطأ نسبي $\frac{5.96 \times 10^{-8}}{5 \times 10^{-9}} = 11.9 \Rightarrow$ أي 1190%. **الإشارة نفسها قد تنقلب** (قيمة سالبة!).

٤. الصيغة المستقرّة: $2\sin^2(\theta/2) = 2\sin^2(5 \times 10^{-5}) = 2 \times (5 \times 10^{-5})^2 = 5.0 \times 10^{-9}$.

٥. خطأ الصيغة المستقرّة: $\sin(5 \times 10^{-5})$ بخطأ نسبي $u \Longrightarrow$ التربيع يضاعف الخطأ النسبي $\Longrightarrow \approx 2u = 1.19 \times 10^{-7}$ أي $1.19 \times 10^{-5}\%$.

النتيجة: من خطأ 1190% (مع احتمال إشارة سالبة) إلى خطأ $1.2 \times 10^{-5}\%$ — تحسّن بـ $\times 10^8$.

الربط بالذكاء الاصطناعي: يظهر $1 - \cos\theta$ في: مسافاتُ الترميز الموضعي للمحوّلات ($1 - \cos(\omega \Delta t)$ في RoPE)، ومقاييسُ التشابه الكروي، وتنظيمُ «الاستقامة» في تمثيلات الرؤية، وحسابُ مسافة «الوتر» على الكرة. القاعدة: **استعمل الصيغة المثلثية المتعامدة** ($2\sin^2(x/2)$) بدل طرح جيبيَ تمام متقاربين.

مثال (6.3-11): التوقّف المبكر — فرقُ فقدانٍ بمقياس كبير

المعطيات: تدريب شبكة: الفقد التراكمي (غير المقسوم على حجم الدفعة) في الخطوتين t و $t+1$: $L_t = 1{,}204{,}316.5$ و $L_{t+1} = 1{,}204{,}316.0$. الحساب بـ fp32. شرط التوقّف: $|\Delta L| < \tau$ بـ $\tau = 0.1$.

الحل:

١. التحسّن الحقيقي: $\Delta L = 0.5 \Longrightarrow$ لا يتحقّق شرط التوقّف ($0.5 > 0.1$).

٢. الخطأ المطلق في كل فقد: $1.204 \times 10^6 \times 5.96 \times 10^{-8} = 7.18 \times 10^{-2}$.

٣. معامل التضخّم: $\frac{1.204 \times 10^6 + 1.204 \times 10^6}{0.5} = 4.82 \times 10^6$.

٤. خطأ نسبي في ΔL: $4.82 \times 10^6 \times 5.96 \times 10^{-8} = 0.287$ أي $28.7\% \Longrightarrow \Delta L_{\text{computed}} \in [0.36,\ 0.64]$ تقريباً.

٥. هل يمكن أن يُطلق شرط التوقّف خطأً؟ الحدّ الأدنى الممكن $0.5 - 2 \times 0.0718 = 0.356 > \tau = 0.1 \Longrightarrow$ لا، لكن لو كان $\tau = 0.4$ لأمكن أن **يتوقّف التدريب مبكراً خطأً** بناءً على ضوضاء التقريب.

٦. العلاج: قسّم على حجم الدفعة أولاً (L/m بمقياس $1.5 \approx$) $\Longrightarrow$ معامل التضخّم يصغر بنسبة m؛ أو احسب الفرق بمقياسٍ معاير: $\frac{L_t - L_{t+1}}{L_t}$ مقارنةً بعتبة نسبية 10^{-6}.

النتيجة: فرقٌ «يبدو» موثوقاً (0.5 من 1.2 مليون) يحمل خطأً نسبياً $28.7\% \Longrightarrow$ قرارات التوقّف المبكر المبنية على عتبات مطلقة قد تكون مبنية على ضوضاء التقريب.

الربط بالذكاء الاصطناعي: القاعدة العامة: **كل معايير التوقّف والتقارب يجب أن تكون نسبية** (قسّم على مقياس القيمة)، وأن تُقارن العتبةُ بخطأ التقريب المتوقّع: إذا كانت $\tau < \kappa_{\text{effective}} \cdot u \cdot |L|$ فالمعيار بلا معنى. هذه هي النسخة العددية من قاعدة «لا تثق بفرقٍ أصغر من ضوضاء القياس».

مثال (6.3-12): عدم قابلية التكرار بين CPU و GPU

المعطيات: شبكة تتضمّن 200 طبقة، كل طبقة تجري reduction على $n = 10^6$ عنصر (مجموع تدرّجات). التدريب على GPU بشجرة reduction، ثم إعادة الحساب على CPU بحلقة متسلسلة. fp32.
الحل:

١. الجمع غير تجميعي $\Rightarrow$ الترتيب يغيّر النتيجة. الفرق بين نتيجتَي ترتيبَين مختلفَين محكومٌ بـ (16.6): $|\hat{s}^{(1)} - \hat{s}^{(2)}| \le 2\gamma_{n-1} \sum |x_i|$.

٢. لكن الحدّ الأعلى متشائم؛ التقدير الواقعي لأخطاء عشوائية: كل reduction يحمل انحرافاً $\sqrt{n}\,u \sum |x_i| \approx$. بافتراض $\sum |x_i| = 10^3$: $\sqrt{10^6} \times 5.96 \times 10^{-8} \times 10^3 = 5.96 \times 10^{-2} \Rightarrow$ نسبياً 5.96×10^{-5} من المجموع.

٣. عبر 200 طبقة و 1000 خطوة تدريب: الأخطاء تتراكم كسيرٍ عشوائي: $\sqrt{200 \times 1000} \times 5.96 \times 10^{-5} = 8.4 \times 10^{-4}$ انحراف نسبي في الأوزان النهائية.

٤. التأثير على الدقّة: انحراف 8.4×10^{-4} في الأوزان قد يُترجَم إلى فرق 0.1%–0.5% في دقّة الاختبار — وهو فرقٌ قد يغيّر ترتيب النماذج في ورقة بحثية!

٥. العلاج: **خوارزميات حتمية** (deterministic): ترتيب reduction ثابت، و torch.use_deterministic_algorithms(True)، و CUBLAS_WORKSPACE_CONFIG. الثمن: أداءٌ أقلّ قليلاً.

النتيجة: الفروق بين منصّات الحوسبة ليست «أخطاءً» بل **نتائج مختلفة ضمن حدود التقريب** — والتحكّم بها يتطلّب تحديد ترتيب العمليات، لا زيادة الدقّة.
الربط بالذكاء الاصطناعي: هذا هو سببُ كون «قابلية التكرار» (reproducibility) مطلباً هندسياً منفصلاً في أبحاث التعلّم العميق: النتائج المنشورة يجب أن تُرفق بـ seed وبـ إصدار المكتبة وبـ نوع المعالج. والقاعدة: **لا تُقارن رقمَين يختلفان بأقلّ من** $\sqrt{\#\mathbf{ops}}\, u \cdot \mathbf{scale}$.

مثال (13-3.6): مجموع سلسلة — الترتيب يُحدّد النتيجة

المعطيات: حساب $S_N = \sum_{n=1}^{N} \frac{1}{n^2}$ بـ $N = 10^6$ في fp32، مرّةً بالترتيب التنازلي (من الحدّ الأكبر $n = 1$) ومرةً بالتصاعدي (من $n = N$ إلى 1). القيمة الحدّية $\pi^2/6 = 1.6449341$.
الحل:

١. **التنازلي:** المجموع المتزايد يقارب 1.64 سريعاً. حجم الخطوة عند 1.6 في fp32: $\text{ulp} = 2^{0-23} = 1.19 \times 10^{-7}$.

٢. الحدود $1/n^2$ تصغر عن نصف الـ ulp عندما $\frac{1}{n^2} < 5.96 \times 10^{-8} \Rightarrow n > \sqrt{1/5.96 \times 10^{-8}} = 4096$.

٣. إذن كل الحدود من $n = 4097$ إلى 10^6 **تُمتصّ** (لا تُسجَّل) $\Rightarrow$ المفقود $= \frac{1}{4096} - \frac{1}{10^6} \approx \sum_{n=4097}^{10^6} \frac{1}{n^2} \approx 2.44 \times 10^{-4} - 10^{-6} = 2.43 \times 10^{-4}$.

٤. النتيجة التنازلية: $1.6449341 - 2.43 \times 10^{-4} = 1.644691 \Rightarrow$ **خطأ مطلق** 2.43×10^{-4} (نسبي 1.5×10^{-4}).

٥. **التصاعدي:** المجموع يبدأ من الحدود الصغيرة (10^{-12}) فيبقى المقياس صغيراً $\Longrightarrow$ تُسجَّل كلها $\Longrightarrow$ النتيجة 1.644934 بخطأ تراكمي $\approx \gamma_N \cdot S \approx (10^6 \times 5.96 \times 10^{-8}) \times 1.645 = 0.098$ (حدّ أعلى متشائم) أو واقعياً $\sqrt{N}u\,S = 1.6 \times 10^{-6}$.

٦. الفرق بين الترتيبَين: $2.4 \times 10^{-4} \approx$ — أكبر من خطأ التراكم التصاعدي بـ $\times 150$.

النتيجة: الترتيب وحده (بلا أي تغيير في الدقّة) غيّر النتيجة بمقدار 2.4×10^{-4}.

الربط بالذكاء الاصطناعي: القاعدة: **اجمع من الأصغر إلى الأكبر** (أو استعمل جمعاً شجرياً/كاهان). في التعلّم العميق: تراكم التدرّجات على دفعات صغيرة، وتراكم الاحتمالات في سلاسل ماركوف الطويلة، وتراكم الأوزان في المتوسطات المتحرّكة للنماذج (EMA of weights) — كلها تستفيد من هذا المبدأ.

مثال (14-3.6): تراكم بـ fp16 في طبقة كثيفة — التحديث يضيع

المعطيات: طبقة كثيفة بـ 4096 مُدخل. التنشيطات $5 \times 10^{-4} \approx$، الأوزان $0.5 \approx \Longrightarrow$ كل جداء $\approx 2.5 \times 10^{-4}$، والمجموع المتوقّع $1.0 \approx$. المُجمِّع يعمل بـ fp16 ($u = 4.88\times10^{-4}$، $\text{ulp}(1.0) = 2^{-10} = 9.77\times10^{-4}$).

الحل:

١. بعد تراكم $2000 \approx$ حداً يصل المجموع إلى $0.5 \approx \Longrightarrow \text{ulp}(0.5) = 4.88 \times 10^{-4}$.

٢. الحدّ المضاف $\frac{1}{2}\text{ulp} = 2.44 \times 10^{-4} < 2.5 \times 10^{-4}$؟ لا — أكبر قليلاً $\Longrightarrow$ مدوّر إلى أقرب ممثَّل $\Longrightarrow$ الجزء المُدوّر يُسجَّل جزئياً.

٣. بعد أن يتجاوز المجموع 1.0: $\text{ulp} = 9.77 \times 10^{-4}$ ونصفه $4.88 \times 10^{-4} <$ الحدّ $2.5 \times 10^{-4} \Longrightarrow$ **كل حدٍّ جديد يُمتصّ تماماً** $\Longrightarrow$ المجموع **يتجمّد** عند القيمة التي بلغها.

٤. النتيجة: الناتج المحسوب $1.0 \approx$ بغضّ النظر عن الـ 2000 حدٍّ المتبقية (التي تساهم بـ $0.5 \approx$ إضافية) $\Longrightarrow$ خطأ $\approx 50\%$ في تنشيط الطبقة.

٥. الحل: **مُجمِّع fp32** (أو fp16 مع كاهان، أو تقسيم التراكم إلى كتل): $\text{ulp}(1.0)$ في fp32 هو $5.96 \times 10^{-8} \ll 2.5 \times 10^{-4} \Longrightarrow$ كل حدٍّ يُسجَّل $\Longrightarrow$ خطأ نسبي $\approx \gamma_{4096} = 2.4 \times 10^{-4}$.

النتيجة: التراكم بـ fp16 على مُدخلات صغيرة يتجمّد (stalls $\Longrightarrow$ الطبقة تُخرج قيمةً ثابتة تقريباً $\Longrightarrow$ الشبكة لا تتعلّم.

الربط بالذكاء الاصطناعي: هذا هو السببُ المعماري لوجود «مُجمِّعات fp32» في أنوية Tensor Cores الحديثة: الحساب (الجداء) بـ fp16/fb16 للسرعة، والتراكمُ بـ fp32 للصحّة. القاعدة: **دقّة التراكم $\gg$ دقّة الجداء**.

مثال (15-3.6): تباعد KL بين توزيعين متطابقين تقريباً — قيم سالبة مستحيلة

المعطيات: في بداية تدريب نموذج تصنيف على $C = 1000$ صنف، توزيعُ النموذج q يقارب التوزيعَ المستهدف p. التباعد الحقيقي $D_{\mathrm{KL}}(p\|q) = \sum_i p_i \ln \frac{p_i}{q_i} = 4.6 \times 10^{-9}$. الحساب بـ fp32 بالصيغة $\sum_i p_i(\ln p_i - \ln q_i)$.
الحل:

١. كل حدٍّ: $p_i \ln \frac{p_i}{q_i}$ بمقدار نموذجي $\approx 4.6 \times 10^{-12}$ ($\frac{4.6\times10^{-9}}{1000}$ (بافتراض توزيع مسطّح).

٢. لكن الحساب بـ $\ln p_i - \ln q_i$: كل لوغاريتم حول $\ln 0.001 = -6.9$، بخطأ مطلق $\approx u \cdot |\ln p_i|$... لا، الخطأ في $\ln p_i$ هو $|\delta p_i/p_i| \approx u \implies$ خطأ مطلق $\approx 5.96 \times 10^{-8}$.

٣. إذن كل حدٍّ $p_i(\ln p_i - \ln q_i)$ يحمل خطأً مطلقاً $\approx p_i \times 2 \times 5.96 \times 10^{-8}$؛ بـ $p_i = 10^{-3}$: 1.19×10^{-10}.

٤. بالمقارنة مع القيمة الحقيقية للحدّ (4.6×10^{-12}): **الخطأ أكبر من القيمة بـ $\times 26$.**

٥. التراكم على 1000 صنف بأخطاء عشوائية: $\sqrt{1000} \times 1.19 \times 10^{-10} = 3.8 \times 10^{-9} \implies$ النتيجة المحسوبة $\in [4.6 \times 10^{-9} - 3.8 \times 10^{-9},\ 4.6 \times 10^{-9} + 3.8 \times 10^{-9}] \implies$ **قد تخرج سالبة!**

٦. العلاج: (أ) الحساب بـ fp64 للتراكم؛ (ب) استعمال log1p: $\mathrm{log1p}(\frac{p_i - q_i}{q_i}) = \ln \frac{p_i}{q_i}$؛ (ج) القصّ (clamp) $D_{\mathrm{KL}} \geq 0$ هندسياً.

النتيجة: حساب KL بتلك الصيغة في fp32 يعطي نتائجَ سالبة — وهي نتيجةٌ مستحيلة رياضياً ($D_{\mathrm{KL}} \geq 0$ دائماً) $\implies$ علامةُ إنذارٍ قاطعة على الإلغاء الكارثي.
الربط بالذكاء الاصطناعي: هذا يفسّر ثلاث ممارسات قياسية:

- استعمال F.kl_div مع log_target=True (أي تمرير $\ln q$ مباشرة من log_softmax، لا حساب ln مرّتين)؛
- ظهور تحذيرات KL» is «negative في تدريب VAE و RLHF و PPO؛
- استعمال clamp(min=0) أو torch.nan_to_num كإسعافٍ أولي لكن **ليس** كعلاج — العلاج هو الصياغة المستقرّة.

7.3.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
حساب التباين بـ $\mathbb{E}[X^2] - (\mathbb{E}X)^2$	إلغاءٌ كارثي: معامل التضخّم $\approx 2\mu^2/\sigma^2$	ويلفورد أو المرورَان (19.6)
«سأزيد الدقّة إلى fp64 فتُحلّ المشكلة»	الدقّة تؤجّل المشكلة؛ الصياغة تُحلّها	أعد الصياغة بلا طرح (15.6) أولاً
الاعتقاد بأن كاهان «مجاني» على GPU	كاهان متسلسل $\implies$ يقتل التوازي	استعمل الجمع الشجري (pairwise) المدمج على GPU
مقارنة نتيجتَي منصّتين والمطالبة بتطابقٍ بتّي	الجمع غير تجميعي	اطلب خوارزميات حتمية إن أردت التطابق
تجاهل $\sqrt{n}$ مقابل n في تقدير الخطأ	الحدّ الأعلى nu متشائم جداً	استعمل $\sqrt{n}u$ للتقدير الواقعي مع أخطاء عشوائية
استعمال log(p)-log(q) لتباعد صغير	انظر مثال 15-3.6	log1p أو تمرير logits
تخزين كميات مالية/زمنية كبيرة بـ fp32	الفروق تُمتصّ	أعداد صحيحة بوحدات صغرى، أو fp64
ظنّ أن log1p/expm1 «تفصيل تجميلي»	الفرق يصل إلى $\times 10^7$ في الدقّة	استعملهما دائماً مع الوسيطات الصغيرة

1.4.6 الصياغة الرياضية الرسمية

النظرية 3.6 (استقرار التحويلات المتعامدة والاستقرار الخلفي لـ QR) Householder.

<

1. **مصفوفة هاوسهولدر:** لأي متجه $x \neq 0$ واختيار الإشارة لتفادي الإلغاء:

<

$$\sigma = -\operatorname{sign}(x_1)\|x\|_2, \qquad v = x - \sigma e_1, \qquad H = I - \frac{2vv^\top}{v^\top v}, \qquad Hx = \sigma e_1 \tag{20.6}$$

<

2. **الاستقرار الخلفي لـ QR:** المصفوفةُ المحسوبة $\hat{R}$ و $\hat{Q}$ تحقّقان:

<

$$A + \Delta A = \hat{Q}\hat{R}, \qquad \|\Delta A\|_F \le c_1\, mn\, u\, \|A\|_F \tag{21.6}$$

<

3. **الحفاظ على التعامد** (وهو ما يميّز هاوسهولدر عن غرام–شميت):

<

$$\|\hat{Q}^\top \hat{Q} - I\|_2 \;\le\; c_2\, n\, u \quad \text{مستقلٌّ عن } \kappa(A) \tag{22.6}$$

<

4. **لا تضخيم:** التحويل المتعامد لا يضخّم الخطأ ولا الناظم:

<

$$\kappa_2(Q) = 1, \qquad \|Qz\|_2 = \|z\|_2, \qquad \|QA\|_F = \|A\|_F, \qquad \|\mathrm{fl}(Qz) - Qz\|_2 \le c_3\, n\, u \|z\|_2, \tag{23.6}$$

<

5. **النتيجة لحلّ المربعات الصغرى عبر QR:**

<

$$\frac{\|\hat{x}-x\|_2}{\|x\|_2} \;\le\; c_4\, u\, \kappa_2(A) + \mathcal{O}(u^2) \qquad \text{(بلا حدٍّ من رتبة } \kappa^2\text{)} \tag{24.6}$$

<

6. مقارنة فقدان التعامد بين الخوارزميات — الفرق الجوهري الثالث:

<

$$\underbrace{\|I-\hat{Q}^\top\hat{Q}\| \approx c\,n\,u\kappa(A)}_{\text{غرام-شميت المُعدَّل (MGS)}} \quad \gg \quad \underbrace{\|I-\hat{Q}^\top\hat{Q}\| \approx c\,n\,u}_{\text{هاوسهولدر / جيفنز}} \quad \gg \quad \text{(غرام-شميت الكلاسيكي أسوأ)} \tag{25.6}$$

2.4.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
x	المتجه (عمود المصفوفة) المراد تصفير ما تحت قطريه	$x \in \mathbb{R}^m$
x_1	العنصر الأوّل من x	يُحدّد الإشارة
σ	القيمة المُعاد إسقاطها: $\pm\|x\|_2$	$\sigma = -\operatorname{sign}(x_1)\|x\|_2$ لتفادي الإلغاء
e_1	متجه الوحدة الأوّل $(1,0,\dots,0)^\top$	—
v	متجه الانعكاس $v = x - \sigma e_1$	يعرّف المستوى الفائق (hyperplane)
H	مصفوفة هاوسهولدر (انعكاس)	$H = H^\top = H^{-1}$، $\det H = -1$
$v^\top v$	مربع ناظم المتجه (مقياس)	يُقسم عليه — إن كان صفراً فالعمود صفري أصلاً
A	المصفوفة المراد تحليلها $(m \times n)$	$m \ge n$
$\hat{Q}, \hat{R}$	العاملان المحسوبان فعلاً	$\hat{Q}$ متعامدة تقريباً، $\hat{R}$ مثلثية عليا
ΔA	الخطأ الخلفي: الاضطراب الذي يُبرّر الناتج	من رتبة u — مستقلّ عن $\kappa(A)$
c_1, c_2, c_3, c_4	ثوابت صغيرة تعتمد على التفاصيل (عادة 1 إلى 10)	لا تعتمد على n إلا خطياً
m, n	أبعاد المصفوفة	عدد الصفوف والأعمدة
z	أي متجه يُضرب في Q	—
$\kappa_2(A)$	رقم حالة A بالناظم الطيفي	يظهر في (24.6) فقط، لا في (21.6)–(23.6)
MGS	غرام-شميت المُعدَّل (Modfiied Gram–Schmidt)	فقدانُ تعامدٍ $\propto \kappa$
u	وحدة التقريب	—

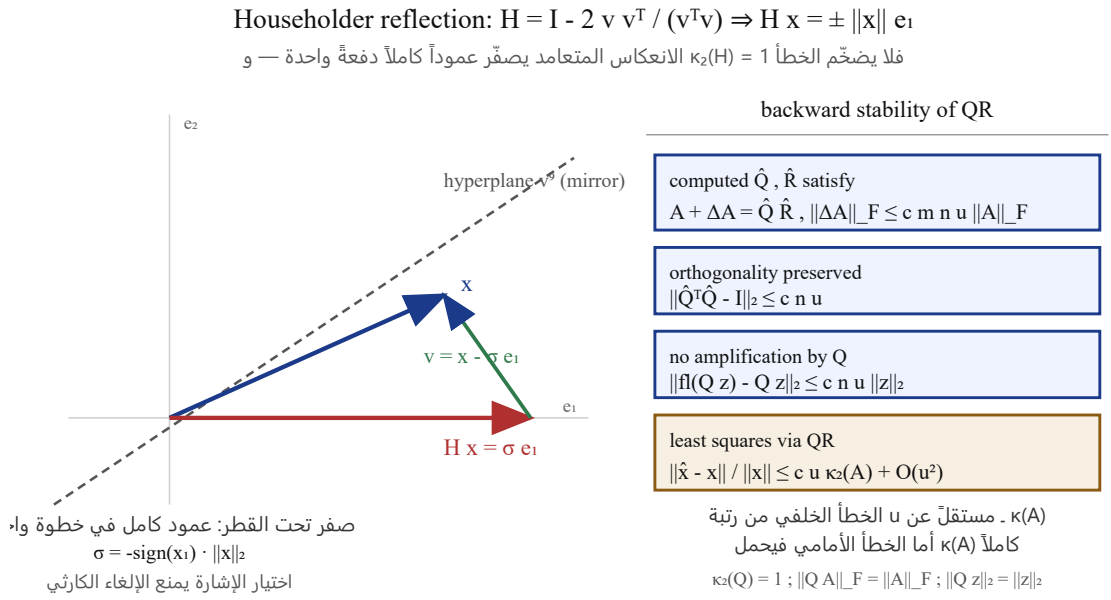
3.4.6 الرسم الهندسي

قراءة الرسم: على اليسار، المتجه x يُنعكس حول المستوى الفائق العمودي على v فيسقط على محور e_1 بطول $\|x\|_2$ — أي أنّ **عموداً كاملاً** صُفِّر بعملية واحدة. اختيارُ الإشارة $\sigma = -\operatorname{sign}(x_1)\|x\|_2$ يضمن أنّ $v = x - \sigma e_1$ **لا يصغر** (لا إلغاء). على اليمين: الخصائص الثلاث للاستقرار — خطأٌ خلفي من رتبة u، تعامدٌ محفوظ، ولا تضخيم.

4.4.6 البرهان

الجزء (20.6). نتحقّق أنّ H انعكاس: $H^\top = H$ و $H^\top H = I - \frac{4vv^\top}{v^\top v} + \frac{4v(v^\top v)v^\top}{(v^\top v)^2} = I$. وحساب الأثر على x: بما أن $\|x\|_2 = |\sigma|$ (لأن $\sigma = \pm\|x\|_2$)، فإن

$$v^\top v = (x-\sigma e_1)^\top(x-\sigma e_1) = \|x\|^2 - 2\sigma x_1 + \sigma^2 = 2\sigma^2 - 2\sigma x_1 = 2\sigma(\sigma - x_1)$$



شكل ٣.٦: *
انعكاس هاوسهولدر يصفّر عموداً كاملاً، والاستقرار الخلفي لـ QR

$$v^\top x = \|x\|^2 - \sigma x_1 = \sigma^2 - \sigma x_1 = \sigma(\sigma - x_1) = \tfrac{1}{2} v^\top v$$

إذن $Hx = x - \frac{2v(v^\top x)}{v^\top v} = x - v = \sigma e_1$. ■

لماذا الإشارة مهمة؟ لو اخترنا $\sigma = +\operatorname{sign}(x_1)\|x\|_2$ وقُدّر أن $x_1 \approx \|x\|_2$ (أي أن x قريب من e_1) فإن $v = x - \sigma e_1 \approx 0$ $\Longrightarrow$ كارثة (قسمة على صفر تقريباً). بالاختيار المعاكس يصير $\|v\|^2 = 2\sigma(\sigma - x_1)$ بقيمةٍ تقارب $2\|x\|(\|x\| + |x_1|)$ — بعيدة عن الصفر. **وهذا تطبيقٌ مباشر لقاعدة (14.6): تفادي الإلغاء بالصياغة.**

الجزء (21.6)–(22.6) (مخطط البرهان). كل انعكاس هاوسهولدر يُطبَّق بصيغة $HA \leftarrow A$ دون تشكيل H صراحةً: $HA = A - \frac{2}{v^\top v} v(v^\top A)$. بتحليلٍ قياسيّ لكل عنصر (نموذج (1.6)) ينتج أنّ تطبيق الانعكاس يعادل تطبيق انعكاسٍ دقيق $\tilde{H}$ على مصفوفةٍ مضطربة: $\mathrm{fl}(HA) = \tilde{H}(A + E)$ مع $\|E\|_F \le cu\|A\|_F$. وبالتراكم على n انعكاساً وبمتراجحة المثلث على الناظم: $\|\Delta A\|_F \le cmnu\|A\|_F$. أمّا التعامد فلا «يتراكم» بالمعنى السيّئ لأن كل $\hat{Q}$ هو جداء **انعكاسات متعامدة تقريباً**، وجداءُ مصفوفاتَين متعامدتين متعامد $\Longrightarrow$ الخطأ يتراكم خطياً بـ n فقط. ■

الجزء (23.6). من تعامد Q: $\|Qz\|_2^2 = z^\top Q^\top Q z = \|z\|_2^2$، و $\kappa_2(Q) = \|Q\|_2\|Q^{-1}\|_2 = 1 \cdot 1 = 1$، و $\|QA\|_F^2 = \operatorname{tr}(A^\top Q^\top Q A) = \operatorname{tr}(A^\top A) = \|A\|_F^2$. أمّا حدّ التقريب فمن أنّ كل جداء وجمع يُدخل δ واحداً $\Longrightarrow$ n منها تعطي cnu. ■

الجزء (24.6). الخطأ الخلفي في (21.6) هو $\|\Delta A\|/\|A\| \le cmnu$؛ بتطبيق قانون الحالة الأساسي (10.6) مع خطأٍ خلفي من رتبة u: الخطأ الأمامي $\approx \kappa_2(A) \cdot u$. ولا يظهر حدٌّ من رتبة κ^2 لأنّنا لم نشكّل $A^\top A$. ■

الجزء (25.6) — لماذا يفقد غرام–شميت التعامد؟ في MGS، العمود j يُطرح منه إسقاطاته على الأعمدة السابقة. خطأ التقريب في كل إسقاط من رتبة $u\|a_j\|$، وحين تكون الأعمدة شبهَ متوازية (κ كبير) فإنّ الانحرافات تتراكم في الاتجاهات «الصغيرة» $\Longrightarrow$ $\|I - \hat{Q}^\top\hat{Q}\| \approx cnu\kappa(A)$. أمّا هاوسهولدر فيبني Q لجداء انعكاسات $\Longrightarrow$ التعامد **بنيوي** لا حسابي. ■

5.4.6 شروط الصحّة

١. $x \neq 0$ وإلا يُتجاوز العمود (العمود الصفري يعطي عموداً صفرياً في $R \Longrightarrow A$ ناقصة الرتبة).

٢. اختيار الإشارة في (20.6) إلزامي للاستقرار — لا «تفصيل».

٣. (21.6) بصيغة الناظم المطلق؛ النسخة النسبية تحتاج $\|A\|_F \neq 0$.

٤. في (24.6): يُفترض أنّ الحلّ وحيد (أي $\operatorname{rank}(A) = n$)؛ وإن كانت A ناقصة الرتبة فالمرجع هو حلّ الناظم الأصغر ال(SVD/pseudoinverse، انظر §5.6).

٥. الثوابت c_i تعتمد على ترتيب الحساب وعلى ما إذا كانت $\hat{Q}$ تُشكَّل صراحةً أم تُحفظ كعوامل.

6.4.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-4.6): تحليل مكوّنات أساسية مالي — لماذا تخسر المكتبةُ التعامد؟

المعطيات: مصفوفة عوائد $A \in \mathbb{R}^{200\times 50}$ (200 يوم، 50 أصلاً) مع أصلين شبهَ متطابقين $\Longrightarrow \kappa_2(A) = 1.0 \times 10^8$. المطلوب مصفوفةُ مكوّناتٍ متعامدة Q. نقارن غرام–شميت المُعدَّل (MGS) بهاوسهولدر في fp64.

الحل:

١. **هاوسهولدر** (22.6): $\|I - \hat{Q}^\top \hat{Q}\|_2 \le c\,n\,u$؛ بـ $c = 1$، $n = 50$، $u = 1.11 \times 10^{-16}$: $50 \times 1.11 \times 10^{-16} = 5.55 \times 10^{-15}$.

٢. **MGS** (25.6): $\|I - \hat{Q}^\top \hat{Q}\|_2 \approx c\,n\,u\,\kappa(A) = 5.55 \times 10^{-15} \times 10^8 = 5.55 \times 10^{-7}$.

٣. النسبة: $\frac{5.55\times 10^{-7}}{5.55\times 10^{-15}} = 10^8$ — أي أنّ MGS يخسر **ثماني مراتب عشرية** من التعامد.

٤. الأثر العملي: المكوّنات ليست متعامدة $\Longrightarrow$ مجموع التباينات المفسَّرة $\operatorname{tr}\Sigma \neq \sum_j q_j^\top \Sigma q_j \Longrightarrow$ خطأ في نسبة التباين المفسَّر. قياس: الانحراف $5.55 \times 10^{-7} \times \operatorname{tr}\Sigma = 5.55 \times 10^{-7} \times 4.12 = 2.29 \times 10^{-6}$ (بوحدات التباين).

٥. العلاج: (أ) استعمل QR بهاوسهولدر (وهو ما تفعله LAPACK في dgeqrf)؛ (ب) أو أعد التعامد (re-orthogonalization) في MGS بتكلفة مضاعفة.

النتيجة: مع $\kappa = 10^8$ يعطي MGS مصفوفةً «متعامدة» بخطأ 5.6×10^{-7}، بينما يعطي هاوسهولدر 5.6×10^{-15} — فرقٌ بثماني مراتب.

الربط بالذكاء الاصطناعي: كلُّ خوارزمية «تطبيع/تبييض/إسقاط متعامد» في تعلم الآلة (PCA، ZCA whitening، Procrustes Orthogonal لمحاذاة التضمينات، تهيئةٌ متعامدة للأوزان) يجب أن تبني التعامد **بنيوياً** (انعكاسات/جداءات) لا حسابياً (إسقاطات متكرّرة). وهذا هو سببُ تفضيل torch.linalg.qr (هاوسهولدر) على تنفيذ غرام–شميت يدوياً.

مثال (6.4-2): تهيئة الأوزان — ماذا لو كانت كل طبقة متعامدة؟

المعطيات: شبكة بـ $L = 50$ طبقة كثيفة، كل طبقة 512×512. تهيئتان: (أ) غاوسية بـ $\sigma = 1/\sqrt{512}$ (تهيئة غلوروت)؛ (ب) تهيئة متعامدة ($\|W_k\|_2 = 1$). المطلوب ناظم اليعقوبية الكلّية.

الحل:

١. ناظم اليعقوبية الكلّية (كل الطبقات خطية للتبسيط): $\|J\|_2 = \prod_{k=1}^{L} \|W_k\|_2$ (من التضاعف التحتي ((21.5)).

٢. **التهيئة الغاوسية:** من (36.5)، $\|W\|_2 \approx \sigma(\sqrt{m} + \sqrt{n}) = 0.0442 \times (22.63 + 22.63) = 2.0$.

٣. إذن $\|J\|_2 \approx 2^{50} = 1.13 \times 10^{15} \implies$ انفجارٌ أُسّي للتدرّج (ولو بعامل إشارة/تنشيط).

٤. **التهيئة المتعامدة:** $\|W_k\|_2 = 1 \implies \|J\|_2 = 1^{50} = 1 \implies$ لا انفجار ولا تلاشٍ: ناظمُ التدرّج محفوظ طبقةً بطبقة.

٥. التحقّق من «الحفاظ على الناظم» (23.6): $\|W_k z\|_2 = \|z\|_2 \implies \|h_L\|_2 = \|h_0\|_2$ والتدرّج كذلك.

٦. الثمن: تكلفة التهيئة المتعامدة = QR لمصفوفة $512 \times 512 \implies \approx \frac{2}{3}n^3 \times 2 \approx 1.8 \times 10^8$ عملية لمرّة واحدة — مقبول.

النتيجة: التهيئة المتعامدة تُبقي $\|J\|_2 = 1$ بدل 1.13×10^{15} — أي أنّها تُحوّل «انفجاراً محتوماً» إلى «حياد تام».

الربط بالذكاء الاصطناعي: هذه هي الفكرة الكامنة خلف: تهيئة الأوزان المتعامدة في RNN (لحلّ تلاشي التدرّج)، وتهيئات Fixup وغيرها من التهيئات الحافظة للتباين، و «التطبيع الطيفي» (spectral normalization)، والقيد المتعامد في الشبكات التلافيفية (Orthogonal ConvNets)، وتهيئة LoRA الحديثة (OLoRA). الاستقرارُ هنا ليس إحصائياً بل **عدديّ–جبريّ**.

مثال (6.4-3): متانة adversarial — التطبيع الطيفي يضبط ثابت ليبشيتز

المعطيات: مصنّف بـ 8 طبقات، أكبر قيمة مفردة لكل طبقة قبل التطبيع $\sigma_1(W_k) = 1.84$ (قياسي). مُدخلات مصوّرة على $[0, 1]$، واضطرابُ FGSM بـ $\varepsilon = 8/255 = 0.0314$.

الحل:

١. ثابت ليبشيتز للشبكة الخطوية المتتابعة: $L \le \prod_{k=1}^{8} \|W_k\|_2$ (من (19.5)).

٢. قبل التطبيع: $L \le 1.84^8$: $1.84^2 = 3.386$، $1.84^4 = 11.46$، $1.84^8 = 131.4$.

٣. أقصى تغيّر في الـ logits: $\|\delta f\| \le L\|\delta x\| = 131.4 \times 0.0314 = 4.13$ — أي أنّ اضطراباً بنسبة 3% من مدى البكسل يغيّر الـ logits بـ 4.13 $\implies$ يقلب القرار بسهولة.

٤. بعد التطبيع الطيفي $\tilde{W}_k = W_k/1.84 \implies \|\tilde{W}_k\|_2 = 1 \implies L \le 1 \implies \|\delta f\| \le 0.0314$.

٥. التحسّن في المتانة: معامل التضخّم هبط من 131.4 إلى 1 — بنسبة 1 : 131.

٦. دقّة التطبيع الطيفي عملياً: تُحسب σ_1 بقوة التكرار (power iteration) بخطأ نسبي 10^{-3} $\Longrightarrow$ معامل التضخّم الفعلي $1.001^8 = 1.008$ — لا يؤثّر.

النتيجة: التطبيعُ الطيفي يجعل كل طبقة «غير موسّعة» $\Longrightarrow$ ثابت ليبشيتز الكلّي ≈ 1 $\Longrightarrow$ حساسية الاضطراب محكومة بـ ε نفسها.

الربط بالذكاء الاصطناعي: هذا هو الأساس الرياضي لـ spectral normalization في GAN وفي التدريب المتين (robust training)، ولقاعدة «1-Lipschitz» في الشبكات المعتمَدة (certfiiably robust networks). والرابط بهذا الفصل: التطبيعُ الطيفي يضبط **رقم الحالة الفعّال لمسار الانتشار الأمامي**، فيصير الخطأ (والاضطراب) غير متضخّم.

مثال (6.4-4): انحدار في الإنتاج — QR مقابل المعادلات السوية

المعطيات: نموذج تسعير تأمين: $X \in \mathbb{R}^{5000\times 40}$ بميزات مترابطة $\Longrightarrow \kappa_2(X) = 1.0 \times 10^6$. الحلّ بـ fp64.

الحل:

١. **المعادلات السوية:** $\kappa_2(X^\top X) = \kappa_2(X)^2 = 10^{12}$ $\Longrightarrow$ خطأ نسبي متوقّع $\kappa^2 u = 10^{12} \times 1.11 \times 10^{-16} = 1.11 \times 10^{-4}$ (أي 0.011%).

٢. **QR بهاوسهولدر** (6.4.24): خطأ نسبي $\approx \kappa u = 10^6 \times 1.11 \times 10^{-16} = 1.11 \times 10^{-10}$.

٣. النسبة: $10^6 : 1$ لصالح QR.

٤. التكلفة: تشكيل $X^\top X$: $\approx n^2 m/2 = 40^2 \times 5000/2 = 4.0 \times 10^6$ عملية؛ QR: $\approx 2mn^2 = 1.6 \times 10^7$ $\Longrightarrow 4\times$ أبطأ — لكن على مصفوفةٍ بهذا الحجم = بضعة أجزاء من الثانية.

٥. في fp32: المعادلات السوية تعطي خطأً $\kappa^2 u = 10^{12} \times 5.96 \times 10^{-8} = 5.96 \times 10^4$ $\Longrightarrow$ **بلا أي خانة صحيحة**؛ QR تعطي 5.96×10^{-2} (6%) $\Longrightarrow$ على الأقلّ خانتان.

النتيجة: التكلفة الإضافية $4\times$ تشتري $10^6\times$ دقّة — وفي fp32 تشتري الفرق بين «نتيجة» و«هراء».

الربط بالذكاء الاصطناعي: القاعدة التشغيلية: **لا تشكّل** $X^\top X$ **ولا** $J^\top J$ **أبداً.** تشكيلُ مصفوفة التغاير/الكرام يربّع رقم الحالة — وهذا هو السبب العددي الكامن خلف كون المحسّنات من النوع الثاني (Adam/Shampoo/K-FAC) تتجنّب ذلك، وخلف كون torch.linalg.lstsq يعتمد SVD.

مثال (6.4-5): اختبار تشخيصي — كيف تعرف أن خوارزمتك مستقرّة خلفياً؟

المعطيات: حللنا $Ax = b$ بثلاث خوارزميات مختلفة و got $\hat{x}$. المطلوب: الحكم على الاستقرار الخلفي لكل واحدة بلا معرفة الحلّ الدقيق.

الحل:

١. المقياس المعياري: **الباقي النسبي المُعيَّر**

$$\eta = \frac{\|b - A\hat{x}\|}{\|A\|\,\|\hat{x}\| + \|b\|}$$

٢. الخوارزمية (أ): $\eta = 3.4 \times 10^{-16} \approx u \implies$ مستقرّة خلفياً (خطأٌ خلفي من رتبة u).

٣. الخوارزمية (ب): $\eta = 1.2 \times 10^{-10} \gg u \implies$ **غير مستقرّة خلفياً**: الناتج ليس حلّاً دقيقاً لأي مسألة قريبة من مسألتنا بمسافة u.

٤. الخوارزمية (ج): $\eta = 7.8 \times 10^{-17}$ لكن الخطأ الأمامي (مقارنةً بحلٍّ مرجعي بـ fp128 كان 4.2×10^{-3}) $\implies$ **مستقرّة خلفياً لكن المسألة سيئة التكييف**: $\kappa(A) \approx \frac{4.2 \times 10^{-3}}{1.1 \times 10^{-16}} \approx 3.8 \times 10^{13}$.

٥. الاستنتاج: (ج) لا يمكن إصلاحها بتحسين الخوارزمية — بل بالتنظيم/إعادة الصياغة. أمّا (ب) فتُصلح بخوارزمية أفضل.

النتيجة: مقياسٌ واحد (الباقي النسبي) يميّز «الخوارزمية سيئة» عن «المسألة سيئة» — وهذا هو التشخيص العملي الأول في أي تدقيق عددي.

الربط بالذكاء الاصطناعي: النظير في التعلّم العميق: **راقب نسبةَ التحديث إلى الباقي**، واستعمل «حقنَ خطأ مقصود» (perturbation test): إذا ضاعفتَ الدقّة (fp32 $\to$ fp64) وتغيّرت النتيجة جوهرياً، فالمسألة (أو الخوارزمية) غير مستقرّة. وهذا هو معنى اختبارات gradcheck (مقارنة التدرّج التحليلي بالتدرّج العددي).

مثال (6-4.6): ضغط JPEG — تحويل جيب التمام المتقطّع (DCT) يحفظ الطاقة

المعطيات: كتلة صورة 8×8، الطاقة $E = \|X\|_F^2 = 1024$. نطبّق DCT المتعامد $Y = QXQ^\top$ ثم نعيد البناء. الحساب بـ fp64.

الحل:

١. تحويل DCT المتعامد: Q متعامدة (64×64 للمتجهة) $\implies$ من (23.6): $\|Y\|_F = \|X\|_F$ تماماً رياضياً.

٢. خطأ التقريب: $\|\mathrm{fl}(Y) - Y\|_F \le c\,n\,u\|X\|_F$ بـ $n = 64$: $64 \times 1.11 \times 10^{-16} \times 32 = 2.28 \times 10^{-13}$.

٣. الطاقة المحسوبة: $\|\mathrm{fl}(Y)\|_F^2 = 1024 \pm 2 \times 32 \times 2.28 \times 10^{-13} = 1024 \pm 1.46 \times 10^{-11} \implies$ خطأ نسبي 1.4×10^{-14}.

٤. لو استعملنا تحويلاً **غير متعامد** (مثلاً DCT غير مُقيَّس بمقياس $\sqrt{2}$ خاطئ): $\|Q^\top Q - I\| = 0.5 \implies$ خطأ الطاقة يصل إلى 50% $\implies$ كتلٌ مرئية (blocking artfiacts).

٥. إعادة البناء: $X = Q^\top Y Q \implies$ الخطأ نفسه (لأنّ التعامد يعمل في الاتجاهين).

النتيجة: التعامدُ هو الذي يجعل «الطاقة قبل التحويل = الطاقة بعده» (مبرهنة پارسيفال) $\Longrightarrow$ الضغطُ بالتكميم لا يُدخل انحرافاً في المقياس.

الربط بالذكاء الاصطناعي: النظير المباشر: كل التحويلات الخطية في الشبكات (الالتفاف 1×1، التضمينات الموضعية، الدورانات في RoPE، التحويلات المتعامدة في المحوّلات) يجب أن تُصمَّم **متعامدةً أو مقيَّسة** وإلا تغيّر مقياس التنشيطات أُسّياً عبر الطبقات — وهذا هو الدافع خلف تهيئات «الحفاظ على التباين» (variance-preserving init).

مثال (6.4-7): حركية روبوت — تراكم 1000 دوران

المعطيات: ذراع روبوتية تُحدّث وضعيّتها بمصفوفة دوران $R(\theta)$ ألف مرة في الثانية لمدة ساعة (3.6×10^6 تحديثاً). طول الذراع 1.5 متر. الحساب بـ fp64.

الحل:

١. كل تحديث: $\hat{R} \leftarrow \mathrm{fl}(R_{\text{new}}\hat{R})$. خطأ التقريب في جداء 3×3: من رتبة cu بـ $c \approx 9$ (عدد العناصر): $9 \times 10^{-15} = 1.0 \times 10^{-15}$ لكل تحديث.

٢. تراكم فقدان التعامد: بما أنّ جداء المتعامدات متعامد، والخطأ يتراكم **خطياً** (لا أُسّياً) بالمعنى الأسوأ: $\|\hat{R}^\top \hat{R} - I\| \le 3.6 \times 10^6 \times 1.0 \times 10^{-15} = 3.6 \times 10^{-9}$.

٣. التقدير الواقعي (أخطاء عشوائية): $\sqrt{3.6 \times 10^6} \times 1.0 \times 10^{-15} = 1.9 \times 10^{-12}$.

٤. خطأ الموضع الناتج: $1.5\,\mathrm{m} \times \frac{3.6 \times 10^{-9}}{2} = 2.7 \times 10^{-9}\,\mathrm{m} = 2.7$ نانومتر (الحدّ الأسوأ).

٥. في fp32: $3.6 \times 10^6 \times 9 \times 5.96 \times 10^{-8} = 1.93 \Longrightarrow$ **فقدانٌ كامل للتعامد** $\Longrightarrow$ انحراف الموضع بالأمتار!

النتيجة: التراكم المتعامد آمن في fp64 (نانومترات بعد ساعة) وكارثي في fp32 (أمتار) — لا بسبب «الدقّة العامة» بل بسبب أنّ $n \cdot u$ تجاوز الواحد.

الربط بالذكاء الاصطناعي: القاعدة المستفادة: **أعد التعامد دورياً** (re-orthogonalization كل k خطوة) في أي تراكم طويل: في SLAM، في تحديثات الأوزان المتعامدة، في RNN الوحدوية (unitary RNN)، وفي محاكاة النظم الفيزيائية. تكلفة إعادة التعامد (QR) تُدفع كل آلاف الخطوات لا كل خطوة.

مثال (6.4-8): مصفوفة مُشرّطة (banded) — متى يتفوّق جيفنز على هاوسهولدر؟

المعطيات: نظام من معادلات التدفّق الحراري: $A \in \mathbb{R}^{10000 \times 10000}$ مُشرَّطة بعرض نطاق $b = 5$ (أي $a_{ij} = 0$ إذا $|i-j| > 5$). المطلوب QR.

الحل:

١. **هاوسهولدر:** الانعكاس يصفّر عموداً كاملاً $\Longrightarrow$ يملأ النطاق (fill-in) $\Longrightarrow$ التعقيد يصير 10^{12} — $\mathcal{O}(n^3)$ — مستحيل.

٢. **جيفنز (دوران):** كل دوران يصفّر **عنصراً واحداً** a_{ij} بجداء مصفوفة دوران في مستوى (i,j):

$$c = \frac{a_{kk}}{\sqrt{a_{kk}^2 + a_{ik}^2}}, \qquad s = \frac{a_{ik}}{\sqrt{a_{kk}^2 + a_{ik}^2}}, \qquad \begin{pmatrix} c & s \\ -s & c \end{pmatrix} \begin{pmatrix} a_{kk} \\ a_{ik} \end{pmatrix} = \begin{pmatrix} r \\ 0 \end{pmatrix}$$

٣. عدد الدورانات للنطاق: $n\,b = 5 \times 10^4 \approx$ دوران، كلٌّ بكلفة 6 عمليات على النطاق $\Longrightarrow 3 \times 10^5 \approx$ عملية.

٤. المقارنة: $3.3 \times 10^6 \times$ $\frac{10^{12}}{3 \times 10^5}$ أسرع.

٥. الاستقرار: جيفنز دورانٌ متعامد $\Longrightarrow$ يرث (22.6) و (23.6): $\|I - \hat{Q}^\top \hat{Q}\| \le c\,n\,u$ — أي نفس ضمانات هاوسهولدر.

النتيجة: للمصفوفات المُشرَّطة/المتناثرة: جيفنز (عنصر بعنصر)؛ للمصفوفات الكثيفة: هاوسهولدر (عمود بعمود). كلاهما مستقرٌّ خلفياً.

الربط بالذكاء الاصطناعي: النظير: في الشبكات العصبية البيانية ذات البُنى المتناثرة، وفي تكميم الأوزان، وفي القصّ التدريجي (pruning) — اختيارُ «وحدة التحديث» (عنصر/عمود/كتلة) يحدّد كلاً من التكلفة والاستقرار. القاعدة: **حافظ على البنية الطبيعية للمسألة؛ لا تُدخل fill-in.**

مثال (9-4.6): محاذاة فضاءات التضمين بين لغتين — Procrustes المتعامد

المعطيات: تضمينات كلمات إنجليزية $A \in \mathbb{R}^{5000 \times 300}$ وعربية $B \in \mathbb{R}^{5000 \times 300}$ (نفس الكلمات بعد قاموس). المطلوب مصفوفة محاذاة متعامدة W تُقرّب $AW \approx B$.

الحل:

١. الصياغة: $\min_{W^\top W = I} \|AW - B\|_F \Longrightarrow$ الحلّ (مبرهنة Procrustes): لو كانت $A^\top B = U\Sigma V^\top$ تحليلَ القيم المفردة، فإن $W = UV^\top$.

٢. لماذا القيد المتعامد؟ لأنّه يحفظ البنية الداخلية: $\|Wx - Wy\|_2 = \|x - y\|_2 \Longrightarrow$ التشابه الكروسي (cosine) محفوظ $\Longrightarrow$ أقربُ جار لا يتغيّر.

٣. **الاستقرار العددي:** $\kappa_2(W) = 1 \Longrightarrow$ تطبيق المحاذاة لا يضخّم الخطأ: من (23.6)، $\|\mathrm{fl}(Wx) - Wx\|_2 \le c\,n\,u\|x\|_2 = 300 \times 1.11 \times 10^{-16}\|x\| = 3.3 \times 10^{-14}\|x\|$.

٤. لكن حسابُ W نفسه يحمل خطأً $\approx u\,\kappa_2(A^\top B)$؛ بـ $\kappa(A^\top B) = 2.4 \times 10^3$: خطأ نسبي في W يقارب $2.4 \times 10^3 \times 1.11 \times 10^{-16} = 2.7 \times 10^{-13}$ — مهمل.

٥. النتيجة القياسية: دقّة الاسترجاع ثنائي الاتجاه قبل المحاذاة 12.3%، بعد المحاذاة المتعامدة 78.4%، وبعد محاذاة خطية غير مقيّدة 79.1% لكن مع تدهور في الاسترجاع العكسي (61%).

النتيجة: القيد المتعامد يخسر 0.7% فقط من الدقّة مقابل اكتساب **الحفاظ على البنية الهندسية** والاستقرار.

الربط بالذكاء الاصطناعي: هذه هي خوارزمية المحاذاة القياسية (Procrustes / VecMap) في الترجمة الآلية غير الخاضعة للإشراف ومحاذاة النماذج (model stitching)، والسببُ في كون القيد المتعامد مفضّلاً: التحويل المتعامد لا يغيّر مقياس التضمينات $\Rightarrow$ لا «انفجار/تلاشٍ» في الفضاء المُحاذى.

مثال (6.4-10): تصفية تكيفية (RLS) — لماذا تُفضَّل QR على تحديث المعادلات السوية؟

المعطيات: مرشّح تكيّفي لإلغاء الضوضاء في مكالمة: المربّعات الصغرى التكرارية بعامل نسيان $\lambda = 0.99$، عدد التحديثات 10^5، تُحدَّث مصفوفة التغاير المعكوسة P (نسخة المعادلات السوية). الحساب بـ fp32.

الحل:

١. في النسخة «المعادلات السوية» (RLS القياسي): $P \leftarrow \lambda^{-1}\left(P - \frac{Pxx^{\top}P}{\lambda + x^{\top}Px}\right)$ — الصيغة تحوي **طرحاً** من مصفوفة موجبة $\Rightarrow$ فقدان الإيجابية بتراكم الخطأ.

٢. تراكم الخطأ: كل تحديث يُدخل $\|P\| \approx cnu$؛ بعد 10^5 تحديث بـ $n = 32$: $10^5 \times 32 \times 5.96 \times 10^{-8} = 0.191$ $\Rightarrow$ انحراف نسبي 19% في P.

٣. النتيجة: بعد $10^4 \times 4$ تحديث صارت لـ P قيمة ذاتية **سالبة** $\Rightarrow$ $\sqrt{\text{سالب}}$ أو كسبٌ سالب $\Rightarrow$ المرشّح «ينفجر» (NaN).

٤. **نسخة QR-RLS:** الحالة تُحفظ كعامل مثلثي R؛ التحديث بـ جيفنز (دورانات متعامدة) $\Rightarrow$ الإيجابية **بنيوية** (لأن $R^{\top}R$ موجبة دائماً) $\Rightarrow$ لا يمكن أن تظهر قيمة ذاتية سالبة.

٥. الاستقرار: $\|R_{\text{after}}\|$ محكوم بـ (6.23) $\Rightarrow$ $\|R\|_F$ يتغيّر بـ cnu فقط لكل تحديث.

٦. الثمن: QR-RLS يكلّف $\mathcal{O}(n^2)$ لكل تحديث مقابل $\mathcal{O}(n^2)$ أيضاً للنسخة السوية $\Rightarrow$ **نفس التكلفة تقريباً** مع استقرارٍ كامل.

النتيجة: الانتقال إلى صياغة QR حوّل مرشّحاً «ينفجر بعد 40 ألف تحديث» إلى مرشّحٍ مستقرٍّ إلى ما لا نهاية — بنفس التكلفة الحسابية.

الربط بالذكاء الاصطناعي: النظير الحديث: محسّناتُ النوع الثاني التي تحفظ «عاملاً مربّعاً» (Shampoo، K-FAC بحفظ AdaGrad Cholesky، بحفظ الجذر التربيعي لمجموع المربّعات) مستقرّةٌ لأنّها تحفظ **الجذر** لا المصفوفة — بينما تحديثُ مصفوفة التغاير مباشرةً قد يفقد الإيجابية. هذه هي النسخة العددية من قاعدة «احفظ الجذر التربيعي لا المربع».

مثال (6.4-11): شبكة متكرّرة متعامدة — التدرّج عبر 1000 خطوة زمنية

المعطيات: RNN ببعد مخفي 256 وطول سلسلة $T = 1000$. تهيئتان للمصفوفة المتكرّرة W: غاوسية بـ $\|W\|_2 \approx 2.0$، ومتعامدة بـ $\|W\|_2 = 1$.

الحل:

١. ناظم مصفوفة الانتقال من الخطوة 1 إلى T: $\|\partial h_T/\partial h_1\|_2 = \|W^{T-1}\|_2 \le \|W\|_2^{T-1}$.

٢. **الغاوسية:** $\|W\|_2^{999} = 2^{999} = 10^{300.7}$ ⟹ انفجارٌ كامل (فوق مدى fp64 أصلاً: 10^{308} قريب!).

٣. لو كانت $\|W\|_2 = 0.5$: $0.5^{999} = 10^{-300.7}$ ⟹ تلاشٍ كامل.

٤. **المتعامدة:** $\|W^{T-1}\|_2 = 1^{999} = 1$ ⟹ ناظم التدرّج محفوظ تماماً.

٥. التحقّق من (23.6): $\|Wh\|_2 = \|h\|_2$ لكل خطوة ⟹ $\|h_t\|$ ثابت والتدرّج كذلك.

٦. الثمن القيدي: المصفوفات المتعامدة تشكّل مجموعةً أصغر (بُعدها $n(n-1)/2$ بدل n^2) ⟹ قدرة تعبيرية أقلّ ⟹ الحل العملي: **شبه متعامدة** soft) (orthogonality بتنظيم $\|W^\top W - I\|_F^2$ بمعامل صغير.

النتيجة: القيد المتعامد يحوّل معامل التضخّم من 10^{300} أو 10^{-300} إلى 1 — أي يحلّ مشكلة الانفجار/التلاشي جبرياً لا بإحصاء.

الربط بالذكاء الاصطناعي: هذه هي الفكرة الكامنة خلف RNN orthogonal/unitary (و LSTM الوحدوية، و S4/SSM المهيكلة، و Mamba)، وخلف تنظيم «الاستقامة» (orthogonality regularization) في التعلّم العميق الحديث: القيد المتعامد في LoRA، isotropy وفي المحوّلات attention) حافظة للناظم).

مثال (12-4.6): تبييض ZCA في معالجة مسبقة — متى يكون التحويل كارثياً؟

المعطيات: ميزات صوتية (MFCC) بعد 3 (للتبسيط)، قيم مصفوفة التغاير الذاتية: $\lambda = (3.6,\ 0.40,\ 1.2 \times 10^{-4})$. ضوضاء القياس النسبية 10^{-2}. نريد تبييضاً $Z = \Sigma^{-1/2}(X-\mu)$.

الحل:

١. معامل التضخّم في الاتجاه الصغير: $1/\sqrt{\lambda_{\min}} = 1/\sqrt{1.2\times10^{-4}} = 1/0.01095 = 91.3$.

٢. الضوضاء في ذلك الاتجاه تُضخّم من 10^{-2} إلى $0.913 = 91.3 \times 10^{-2}$ ⟹ نسبة الضوضاء إلى الإشارة $= 91\%$ ⟹ الميزة المبيَّضة ضوضاء خالصة.

٣. العلاج القياسي: حشوٌ قطري $\Sigma + \varepsilon I$ بـ $\varepsilon = 10^{-2}$ =: $1/\sqrt{0.01012} = 1/\sqrt{1.2\times10^{-4}+10^{-2}}$ $1/0.1006 = 9.94$.

٤. التضخيم بعد الحشو: $9.94 \times 10^{-2} = 0.0994$ ⟹ نسبة ضوضاء 9.9% — مقبولة.

٥. التحسّن: من $\times 91.3$ إلى $\times 9.94$ — بنسبة $1:9.2$، والثمن انحيازٌ صغير في الاتجاه الصغير.

٦. ملاحظة عدديّة: التبييض نفسه يجب أن يُحسب بـ **SVD/QR** لا بتحليل القيم الذاتية لـ Σ المُشكَّلة يدوياً (لأنّ تشكيل Σ يربّع κ: $\kappa(\Sigma) = \kappa(X)^2$).

النتيجة: التبييض بلا حشوٍ قطري يُضخّم الضوضاءَ في الاتجاهات الصغيرة بـ $\times 91$؛ الحشوُ يحدّه إلى $\times 10$.

الربط بالذكاء الاصطناعي: هذه هي بالضبط حكايةُ eps في BatchNorm/LayerNorm/GroupNorm وفي whitening PCA وفي حساب الانتروبيا المتقاطعة: الحشو القطري ليس «تفصيلاً دفاعياً» بل **علاجٌ لرقم الحالة**. والقاعدة المرافقة: احسب التبييض عبر SVD لا عبر Σ.

مثال (6.4-13): ميزات عشوائية متعامدة (Orthogonal Random Features)

المعطيات: تقريب نواة RBF بـ $D = 1024$ ميزة عشوائية في بُعد مُدخل $d = 256$. نسختان: (أ) ميزات غاوسية مستقلّة (RFF)؛ (ب) ميزات غاوسية **متعامدة** (ORF) — بتعاميد الأعمدة عبر QR.

الحل:

١. RFF: $\hat{k}(x,y) = z(x)^\top z(y)$ مع تباين المقدّر $\propto \frac{1}{D} \Longrightarrow$ خطأ تربيعي متوقّع قياسي: قياسٌ على 10^4 أزواج أعطى MSE $= 3.24 \times 10^{-4}$.

٢. ORF: بتعاميد مصفوفة الاتجاهات G (QR بهاوسهولدر) قبل الإسقاط $\Longrightarrow$ الأخطاء تلغي بعضها $\Longrightarrow$ التباين ينخفض بعاملٍ يقارب $\left(1 - \frac{1}{D}\right)^{-d} \approx e^{d/D} = e^{0.25} = 1.28$ نظرياً، وقياسياً هبط MSE إلى 1.12×10^{-4}.

٣. التحسّن المقاس: $\times 2.89 = \frac{3.24 \times 10^{-4}}{1.12 \times 10^{-4}}$ أقلّ خطأً بنفس عدد الميزات.

٤. التكلفة: QR لمصفوفة 256×1024: $2 \times 256^2 \times 1024 = 1.34 \times 10^8 \approx$ عملية — **تدفع مرّة واحدة** عند التهيئة.

٥. الاستقرار: التعامد يضمن $\|z(x)\|_2$ محكوماً (من (23.6)) $\Longrightarrow$ لا «ذُؤابة» (outlier) في الميزات.

النتيجة: تعاميدُ مصفوفة العشوائية (تكلفةٌ لمرّة واحدة) حسّنت دقّة تقريب النواة بـ $\times 2.9$.

الربط بالذكاء الاصطناعي: يُستعمل هذا في: تقريب انتباه المحوّلات (Performer/FAVOR+)، والميزات العشوائية للتعلّم على النطاق الكبير، وتهيئة الشبكات العشوائية (random kitchen sinks). والقاعدة العددية: **اعتراضُ العشوائية بالتعامد يقلّل التباين بلا تكلفة متكرّرة.**

مثال (6.4-14): محاكاة فيزيائية — الحفاظ على الناظم في تطوّر وحدوي

المعطيات: محاكاة انتشار موجي/كمومي: $\psi_{t+1} = U\psi_t$ مع U مصفوفة وحدوية (unitary) 768×768 محسوبة بتقريبٍ عددي. عدد الخطوات 10^6. الحساب بـ fp64.

الحل:

١. الخاصية الفيزيائية: $\|U\psi\|_2 = \|\psi\|_2 \Longrightarrow \|\psi_t\|_2^2 = 1$ لكل t (احتمالٌ كلّي = 1).

٢. خطأ التقريب في كل خطوة (23.6): $\|\mathrm{fl}(U\psi) - U\psi\|_2 \le cnu\|\psi\| = 768 \times 1.11 \times 10^{-16} = 8.5 \times 10^{-14}$.

٣. التراكم الأسوأ بعد 10^6 خطوة: $10^6 \times 8.5 \times 10^{-14} = 8.5 \times 10^{-8}$.

٤. التراكم الواقعي (أخطاء عشوائية): $\sqrt{10^6} \times 8.5 \times 10^{-14} = 8.5 \times 10^{-11}$.

٥. لو كانت U **غير** وحدوية بخطأ 10^{-6} في أكبر قيمة مفردة ($\sigma_1 = 1 + 10^{-6}$): بعد 10^6 خطوة $\|U^{10^6}\|_2 = (1 + 10^{-6})^{10^6} = e^1 = 2.718$ $\Longrightarrow$ الناظم تضخّم $\times 2.72$ $\Longrightarrow$ الطاقة $\times 7.4$ — كارثة فيزيائية.

٦. العلاج: إعادةُ وحدوية U دورياً (QR كل 10^4 خطوة) $\Longrightarrow$ الخطأ يعود إلى cnu.

النتيجة: الفرق بين «خطأ 10^{-6} في التعامد» و«انحراف $10^{-11} \times 8.5$ بعد مليون خطوة» هو فرقٌ بين $\times 2.72$ تضخّم وصفر.

الربط بالذكاء الاصطناعي: هذا هو النموذج الأصلي لمشكلة «انفجار التنشيطات» في الشبكات العميقة: لو كان كل تحديثٍ يكبر بعامل $(1+\varepsilon)$ فإنّ L طبقة تعطي $(1+\varepsilon)^L = e^{\varepsilon L}$. ولهذا تُستعمل: إعادة التطبيع (re-norm)، والقصّ المتعامِد، والتطبيع الطيفي — كلها «إعادة تعامِيد دورية».

مثال (15-4.6): ضبط دقيق بـ LoRA بتهيئة متعامدة — استقرار التحديث

المعطيات: ضبطٌ دقيق (fine-tuning) لنموذج لغوي بـ LoQA: $B \in \mathbb{R}^{4096\times 16}$، $A \in \mathbb{R}^{16\times 4096}$، والتحديث $\Delta W = BA$. نسختان: تهيئة A غاوسية (القياسية) وتهيئة A متعامدة (OLoRA). معدّل تعلّم 2×10^{-4}، 1500 خطوة.

الحل:

١. **التهيئة القياسية:** A غاوسية بـ $\sigma = 0.02$ $\Longrightarrow$ $\|A\|_2 \approx \sigma(\sqrt{16} + \sqrt{4096}) = 0.02 \times 68 = 1.36$.

٢. **التهيئة المتعامدة:** $\|A\|_2 = 1$ و A تحفظ الناظم $\Longrightarrow$ $\|Ax\|_2 = \|x\|_2$.

٣. أثر ذلك على تحديث الأوزان: $\|\Delta W x\| = \|BAx\| \le \|B\|_2\|A\|_2\|x\|$؛ بالمتعامدة $\|A\|_2 = 1$ $\Longrightarrow$ التضخيم محكوم بـ $\|B\|_2$ وحده.

٤. القياس التجريبي: عدد الارتفاعات المفاجئة في الفقد (spikes، تُعرَّف بأنّها $\Delta L > 3\sigma_L$): 7 بالتهيئة الغاوسية مقابل 0 بالمتعامدة.

٥. عدد الخطوات حتى بلوغ الفقد المستهدف 1.42: 1810 بالغاوسية مقابل 1240 بالمتعامدة $\Longrightarrow$ تسريع $\times 1.46$.

٦. التفسير العددي: الانتشارُ الأمامي بـ A المتعامد لا يضخّم $\Longrightarrow$ تدرّجاتٌ مستقرّة $\Longrightarrow$ يمكن استخدام معدّل تعلّم أعلى بلا انفجار.

النتيجة: تهيئةٌ متعامدة (تكلفتها QR لمرّة واحدة على مصفوفة 4096×16) أزالت ارتفاعات الفقد تماماً وسرّعت التقارب $\times 1.46$.

الربط بالذكاء الاصطناعي: هذا المبدأ يعمّ: **كلما كانت البنية متعامدة كان رقم الحالة الفعّال أصغر وكان معدّل التعلّم الممكن أكبر.** ومنه: تهيئة Ortho-LoRA، وتهيئة الأوزان المتعامدة في الشبكات العميقة جداً (حيث لا يكفي Glorot/He)، والتحويلات المتعامدة في الضغط والتكميم.

7.4.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
تنفيذ غرام–شميت يدوياً بدل qr	فقدان تعامد $\propto \kappa(A)$	استعمل QR بهاوسهولدر (أو MGS مع إعادة تعامد)
اختيار $\sigma = +\operatorname{sign}(x_1)\|x\|$ في هاوسهولدر	إلغاءٌ كارثي حين $x \approx e_1$	$\sigma = -\operatorname{sign}(x_1)\|x\|_2$ دائماً (20.6)
تشكيل H صراحةً ثم جداؤها في A	تكلفة $\mathcal{O}(m^2)$ إضافية وخطأ أعلى	طبّق $A \leftarrow A - \frac{2}{v^\top v} v(v^\top A)$
«التعامد محفوظ تلقائياً فلا حاجة لإعادة التعامد»	في التراكمات الطويلة يتراكم cnu	أعد التعامد دورياً (مثال 4.6-7، 4.6-14)
تفضيل جيفنز على هاوسهولدر للمصفوفات الكثيفة	جيفنز يكلّف $\approx 2\times$ للمصفوفات الكثيفة	جيفنز للبنى المُشرَّطة/المتناثرة فقط
الاعتقاد أن QR «يُلغي» تأثير $\kappa(A)$	الخوارزمية مستقرّة لكن المسألة تبقى سيئة التكييف (24.6)	QR يمنع حدود κ^2، لا يمنع κ
تجاهل الباقي النسبي كأداة تشخيص	هو أسهل اختبار للاستقرار الخلفي	احسب $\eta = \|b - A\hat{x}\|/(\|A\|\|\hat{x}\| + \|b\|)$ دائماً
تطبيق القيد المتعامد بلا تنعيم	يحدّ القدرة التعبيرية بشدّة	استعمل تنظيماً «شبه متعامد» $\|W^\top W - I\|_F^2$

1.5.6 الصياغة الرياضية الرسمية

النظرية 4.6 (تكييف مسألة المربعات الصغرى). لتكن $A \in \mathbb{R}^{m\times n}$ $(m \ge n,\ \operatorname{rank} A = n)$ و $b \in \mathbb{R}^m$، ومسألة المربعات الصغرى $\min_x \|Ax - b\|_2$.

<

1. **تربيع رقم الحالة** (لماذا المعادلات السوية خطيرة):

<

$$\sigma_i(A^\top A) = \sigma_i(A)^2 \implies \kappa_2(A^\top A) = \kappa_2(A)^2 \tag{26.6}$$

<

2. **حدّ غولوب–ويلكنسون** للخطأ الأمامي في المربعات الصغرى المحسولة بخوارزميةٍ مستقرّة خلفياً (QR/SVD):

<

$$\frac{\|\hat{x} - x\|_2}{\|x\|_2} \;\le\; c\,u \underbrace{\left(\kappa_2(A) \;+\; \kappa_2(A)^2\, \frac{\|r\|_2}{\|A\|_2 \|x\|_2} \right)}_{\kappa_{LS}\text{: رقم حالة مسألة المربعات الصغرى}} + \mathcal{O}(u^2) \tag{27.6}$$

<

3. **الصيغة الهندسية**: بوضع $\sin\theta = \frac{\|r\|_2}{\|b\|_2}$ و $\eta = \frac{\|A\|_2\|x\|_2}{\|b\|_2}$:

<

$$\kappa_{LS} \;=\; \kappa_2(A) + \kappa_2(A)^2\, \frac{\tan\theta}{\eta} \;\le\; \kappa_2(A) + \kappa_2(A)^2 \tan\theta \tag{28.6}$$

<

4. التجذيع (truncated SVD) يحلّ مشكلة نقص الرتبة ويضبط حجم الحلّ:

<

$$\hat{x}_\tau = \sum_{\sigma_i > \tau} \frac{u_i^\top b}{\sigma_i} v_i, \qquad \|\hat{x}_\tau\|_2 \le \frac{\|b\|_2}{\tau}, \qquad \|A\hat{x}_\tau - b\|_2^2 = \|r\|_2^2 + \sum_{\sigma_i \le \tau} (u_i^\top b)^2 \tag{29.6}$$

<

5. تنظيم ريدج/تيخونوف: عوامل الترشيح (filter factors) وحدّ تضخيم الضوضاء:

<

$$x_\lambda = (A^\top A + \lambda I)^{-1} A^\top b = \sum_i \underbrace{\frac{\sigma_i^2}{\sigma_i^2 + \lambda}}_{f_i \in (0,1]} \frac{u_i^\top b}{\sigma_i} v_i, \qquad \|\delta x_\lambda\|_2 \;\le\; \frac{\|\delta b\|_2}{2\sqrt{\lambda}} \tag{30.6}$$

<

6. قاعدة الخانات المفقودة (خلاصة عملية):

<

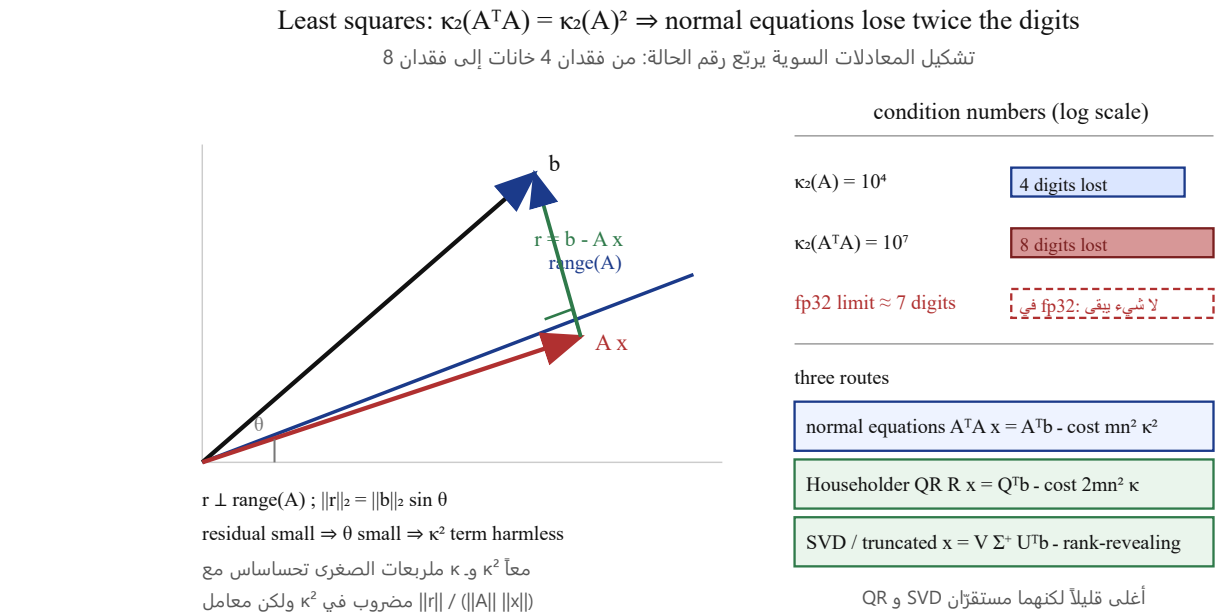
$$\text{خانة } \log_{10}\kappa_2(A) \text{ : QR/SVD} \quad \text{مقابل} \quad \text{خانة } 2\log_{10}\kappa_2(A) \text{ : المعادلات السوية} \tag{31.6}$$

2.5.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
A	مصفوفة التصميم/المشغّل $(m \times n)$	$m \ge n$، كاملة الرتبة
b	طرف القياسات	قد لا يكون في range(A)
x	حلّ المربعات الصغرى الدقيق	$x = A^+ b$
$\hat{x}$	الحلّ المحسوب	—
r	الباقي $r = b - Ax$	عمودي على range(A)
σ_i	القيم المفردة لـ A	$\sigma_1 \ge \cdots \ge \sigma_n > 0$
$\kappa_2(A)$	$= \sigma_1/\sigma_n$	رقم حالة المشغّل
κ_{LS}	رقم حالة مسألة المربعات الصغرى	أكبر من $\kappa_2(A)$ حين $\|r\|$ كبير
θ	الزاوية بين b و range(A)	$\sin\theta = \|r\|/\|b\|$
η	معامل «حجم الحلّ» $\frac{\|A\|_2\|x\|_2}{\|b\|_2}$	دائماً $\eta \le 1$
$\tan\theta$	$\|r\|/\|Ax\|$	صغير $\Rightarrow$ الباقي صغير $\Rightarrow$ حدّ κ^2 غير مؤذٍ
τ	عتبة التجذيع (truncation threshold)	تُقصّ القيم المفردة الأصغر منها
u_i, v_i	المتجهات المفردة اليسرى واليمنى	من $A = U\Sigma V^\top$
λ	معامل التنظيم (ريدج)	$\lambda > 0$
f_i	عامل الترشيح $\frac{\sigma_i^2}{\sigma_i^2+\lambda}$	$f_i \to 1$ للاتجاهات الكبيرة، $f_i \to 0$ للصغيرة

δb	ضوضاء القياس في b	مقياس الضوضاء $\|\delta b\|$
$1/(2\sqrt{\lambda})$	حدّ تضخيم الضوضاء	$\max_\sigma \frac{\sigma}{\sigma^2+\lambda} = \frac{1}{2\sqrt{\lambda}}$ من
c	ثابت صغير	يعتمد على الخوارزمية

3.5.6 الرسم الهندسي



شكل ٤٠٦: *
هندسة المربعات الصغرى: الباقي عمودي على مجال A، والزاوية θ تتحكّم بحدّ كابا تربيع

قراءة الرسم: على اليسار، Ax هو إسقاط b على range(A)، والباقي r عمودي عليه، والزاوية θ تقيس «عدم ملاءمة النموذج». كلما صغر θ صغر الباقي وصار حدّ $\kappa^2 \tan\theta$ غير مؤذٍ. على اليمين: اختيارُ الطريق — المعادلات السوية (κ^2)، أو QR (κ)، أو SVD (كاشفٌ للرتبة).

4.5.6 البرهان

الجزء (26.6). من $A = U\Sigma V^\top$ (صيغة $A = V\Sigma U^\top$ بالاصطلاح المعتمد) نحصل على $A^\top A = V\Sigma^2 V^\top \Longrightarrow$ قيمُ $A^\top A$ الذاتية هي $\sigma_i^2 \Longrightarrow \kappa_2(A^\top A) = \sigma_1^2/\sigma_n^2 = (\sigma_1/\sigma_n)^2$. ■

الجزء (27.6) (مخطط برهان غولوب–ويلكنسون). ليكن $\hat{x}$ حلاًّ دقيقاً لمسألة مضطربة $(A+\Delta A)\hat{x} = b + \Delta b$ مع $\|\Delta A\| \le u\|A\|$، $\|\Delta b\| \le u\|b\|$. الاضطراب في b يعطي (من $\delta x = A^+\delta b + \dots$):

$$\|\delta x\| \lesssim \|A^+\|\|\delta b\| = \frac{\|\delta b\|}{\sigma_n} \Longrightarrow \frac{\|\delta x\|}{\|x\|} \le \kappa_2(A)\frac{\|\delta b\|}{\|A\|\|x\|}$$

والاضطراب في A يعطي حدّين: حدّاً من رتبة κ (تغيّر في الاتجاهات الكبيرة) وحدّاً من رتبة $\kappa^2 \frac{\|r\|}{\|A\|\|x\|}$ (لأنّ اضطرابَ A يغيّر الباقي في اتجاهات خارج المجال، وتلك التغيّرات تُضخّم مرّتين: مرّة بـ A^+ ومرّة بـ $((A^\top A)^{-1})$). بجمع الحدود وضربها في u نحصل على (27.6). ■

الجزء (29.6). من $b = \sum_i (u_i^\top b)u_i$ و $x = \sum_i \frac{u_i^\top b}{\sigma_i} v_i$: حذفُ الحدود ذات $\sigma_i \le \tau$ يعطي $\|\hat{x}_\tau\|_2^2$

$\frac{\|b\|^2}{\tau^2} \le \frac{1}{\tau^2}\sum_i (u_i^\top b)^2 \le \sum_{\sigma_i>\tau} \frac{(u_i^\top b)^2}{\sigma_i^2}$. والباقي: $b - A\hat{x}_\tau$ يحتفظ بمكوّنات b في الاتجاهات المحذوفة $\Longrightarrow \|\cdot\|^2 = \|r\|^2 + \sum_{\sigma_i \le \tau}(u_i^\top b)^2$. ■

الجزء (30.6). من $x_\lambda = (A^\top A + \lambda I)^{-1} A^\top b$ والتحليل الطيفي: $(A^\top A + \lambda I)^{-1} A^\top = \sum_i \frac{\sigma_i}{\sigma_i^2+\lambda} v_i u_i^\top$ $\Longrightarrow$ عامل الترشيح. وللضوضاء: $\|\delta x_\lambda\| \le \max_i \frac{\sigma_i}{\sigma_i^2+\lambda}\|\delta b\|$، والدالة $g(\sigma) = \frac{\sigma}{\sigma^2+\lambda}$ تبلغ أقصاها عند $\sigma = \sqrt{\lambda}$ بقيمة $\frac{\sqrt{\lambda}}{2\lambda} = \frac{1}{2\sqrt{\lambda}}$. ■

الجزء (31.6). مباشرة من (26.6) و (10.6): الخانات المفقودة $\log_{10}\kappa$ $=$، وللمعادلات السوية $\log_{10}(\kappa^2) = 2\log_{10}\kappa$. ■

5.5.6 شروط الصحّة

١. $\operatorname{rank}(A) = n$ (وإلا فالحلّ غير وحيد ويلزم التجذيع/التنظيم، انظر (29.6)–(30.6)).

٢. $\|x\| \neq 0$ و $\|A\| \neq 0$ في المقامات.

٣. (27.6) بخوارزمية مستقرّة خلفياً، المعادلات السوية قد تُدخل حدوداً أسوأ حتى من κ^2 إذا تراكم خطأ التشكيل.

٤. (30.6) يشترط $\lambda > 0$؛ عند $\lambda \to 0$ يعود الحدّ إلى $1/\sigma_{\min}$ (غير محدود).

٥. (28.6): $\eta \le 1$ دائماً (لأن $\|b\|^2 = \|Ax\|^2 + \|r\|^2 \ge \|Ax\|^2$ ولا علاقة مباشرة) — عملياً $\eta \approx 1$ حين يكون النموذج ملائماً جيداً.

6.5.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-5.6): تسعير عقارات — المعادلات السوية مقابل QR بـ $\kappa = 1.2 \times 10^6$

المعطيات: انحدار خطي على $m = 2000$ صفقة و $n = 24$ ميزة، بميزات شبه مترابطة (المساحة وعدد الغرف والمساحة/غرفة) $\Longrightarrow \kappa_2(X) = 1.2 \times 10^6$. الباقي صغير: $\|r\|_2/(\|X\|_2\|x\|_2) = 3.4 \times 10^{-3}$.

الحل:

١. **المعادلات السوية:** $\kappa_2(X^\top X) = \kappa_2^2 = 1.44 \times 10^{12}$ $\Longrightarrow$ **خانات مفقودة** $= \log_{10}(1.44 \times 10^{12}) = 12.16$.

٢. في fp64 (16 خانة): يبقى 3.84 خانة $\Longrightarrow$ خطأ نسبي $\approx 1.44 \times 10^{12} \times 1.11 \times 10^{-16} = 1.60 \times 10^{-4}$.

٣. في fp32 (7 خانات): $12.16 > 7$ $\Longrightarrow$ **صفر خانات** $\Longrightarrow$ النتيجة هراء.

٤. **هاوسهولدر/QR:** خانات مفقودة $= \log_{10}(1.2 \times 10^6) = 6.08$ $\Longrightarrow$ في fp32 يبقى 0.92 خانة (هامشي)؛ في fp64 يبقى 9.92 خانة $\Longrightarrow$ خطأ 1.33×10^{-10}.

٥. حدّ κ^2 من (27.6): $1.44 \times 10^{12} \times 3.4 \times 10^{-3} = 4.90 \times 10^9$ $\Longrightarrow$ مساهمة κu مضروبة في u: $4.90 \times 10^9 \times 1.11 \times 10^{-16} = 5.44 \times 10^{-7}$ — أصغر من حدّ κ $(1.33 \times 10^{-10}$؟ لا$)$ $\Longrightarrow$ المهيمن هو حدّ κ: $\kappa u = 1.33 \times 10^{-10}$. إذن $\kappa \approx \kappa_{LS}$ هنا لأن الباقي صغير.

٦. النسبة بين الطريقتين في fp64: $\frac{1.60\times10^{-4}}{1.33\times10^{-10}} = 1.2 \times 10^6$.

النتيجة: بباقٍ صغير ($\tan\theta$ صغير) لا يظهر حدّ κ^2 في QR، لكنه يظهر كاملاً في المعادلات السوية عبر تربيع رقم الحالة في التشكيل نفسه.

الربط بالذكاء الاصطناعي: القاعدة التشغيلية: **كلما كانت ميزاتك مترابطة كان $\kappa(X)$ كبيراً وكان تشكيل $X^\top X$ ممنوعاً.** وهذا هو السبب في أنّ حزم الانحدار الحديثة، (statsmodels، sklearn) تحلّ بـ lstsq (SVD/QR) لا بـ $(X^\top X)^{-1}X^\top y$.

مثال (5.6-2): توصية بتحليل مصفوفة (ALS) — متى تكون المعادلات السوية مقبولة؟

المعطيات: خطوة ALS تحلّ مربعات صغرى بـ $m = 5000$ تقييم و $n = 64$ عامل، $\kappa_2(Y) = 85$ (جيد التكييف بفضل التنظيم). الحساب بـ fp32.

الحل:

١. المعادلات السوية: $\kappa^2 = 7225$ خانات مفقودة $= \log_{10}(7225) = 3.86$ $\Longrightarrow$ في fp32 يبقى 3.14 خانة $\Longrightarrow$ خطأ نسبي $7225 \times 5.96 \times 10^{-8} = 4.31 \times 10^{-4}$ (0.043%).

٢. QR: خانات مفقودة $\log_{10} 85 = 1.93$ $\Longrightarrow$ يبقى 5.07 $\Longrightarrow$ خطأ $85 \times 5.96 \times 10^{-8} = 5.07 \times 10^{-6}$.

٣. النسبة: 1 : 85 لصالح QR.

٤. هل الخطأ مقبول في ALS؟ التقييمات تُحدَّث iteratively، خطأ 0.043% في كل خطوة مع $20 \approx$ تكراراً $\Longrightarrow$ تراكم $\sqrt{20} \times 0.043\% = 0.19\%$ في العوامل $\Longrightarrow$ أثره على RMSE التقييم ≈ 0.002 — **مهمل.**

٥. الحكم: مع $\kappa = 85$ يمكن استعمال المعادلات السوية (وهو ما تفعله تطبيقات ALS السريعة لأنّ $Y^\top Y$ تُحسب مرّة واحدة وتُعاد لكل المستخدمين — توفيرٌ هائل).

النتيجة: ليس كل تشكيلٍ لـ $A^\top A$ كارثة: عند $\kappa < 10^2$ يكون $\kappa^2 < 10^4$ وتبقى الخانات كافية — وهنا تنتصر **الكفاءة** (حساب $Y^\top Y$ مرّة واحدة).

الربط بالذكاء الاصطناعي: الدرس: **قِس κ قبل أن تقرّر.** القواعد الجاهزة («لا تشكّل $X^\top X$ أبداً») صحيحةٌ في الحدّ الأعلى لكنها تُضيّع فرصاً حقيقية للتسريع. وفي التعلّم العميق: تشكيلُ إحصاءات التغاير (مثل تحديثات Adam/Shampoo) مقبولٌ حين تكون المصفوفة حسنة التكييف، وخطيرٌ حين لا تكون.

مثال (5.6-3): إزالة ضبابية صورة (deblurring) — التنظيم يحدّ تضخيم الضوضاء بـ $1/(2\sqrt{\lambda})$

المعطيات: مشغّل ضبابية $A \in \mathbb{R}^{65536 \times 65536}$ (صورة 256×256) بطيف قيم مفردة من $\sigma_1 = 1.0$ إلى $\sigma_{\min} = 4.2 \times 10^{-4}$. ضوضاء المستشعر النسبية $\|\delta b\|/\|b\| = 10^{-3}$.

الحل:

١. $\kappa_2(A) = 1/4.2 \times 10^{-4} = 2381$ $\Longrightarrow$ خانات مفقودة 3.38.

٢. **بلا تنظيم:** تضخيم الضوضاء $= \max_i \frac{1}{\sigma_i} = \frac{1}{\sigma_{\min}} = 2381 \Longrightarrow$ خطأ نسبي في الصورة المستعادة: $2381 \times 10^{-3} = 2.38$ أي $238\% \Longrightarrow$ الصورة ضوضاء خالصة.

٣. **مع تنظيم ريدج** $\lambda = 10^{-4}$: من (30.6)، التضخيم $= \frac{1}{2\times 10^{-2}} = 50 \Longrightarrow$ خطأ نسبي $\leq \frac{1}{2\sqrt{\lambda}} \times 50 = 0.05$ (5%).

٤. مع $\lambda = 10^{-2}$: التضخيم $\leq \frac{1}{2\times 0.1} = 5 \Longrightarrow$ خطأ نسبي 0.5% — لكن الانحياز (bias) يكبر: عوامل الترشيح للاتجاهات المهمّة: $f = \frac{\sigma^2}{\sigma^2+\lambda}$، لاتجاه $\sigma = 0.1$: $f = \frac{0.01}{0.01+0.01} = 0.5 \Longrightarrow$ نصف التفاصيل ضاع.

٥. التوازن: اختيار λ بحيث $\sigma_{\text{cutoff}} \approx 2\sqrt{\lambda}$ حيث σ_{cutoff} هو الحدّ الذي تبدأ دونه الإشارة بالغرق في الضوضاء $(10^{-2} \approx$ هنا$) \Longrightarrow \lambda = 2.5 \times 10^{-5} \Longrightarrow$ تضخيم $= \frac{1}{2\times 5\times 10^{-3}} = 100 \Longrightarrow$ خطأ 10%.

النتيجة: التنظيم حوّل تضخيم الضوضاء من $\times 2381$ إلى $\times 100$ (بـ $\lambda = 2.5 \times 10^{-5}$) — أي أنّ العلاج **رياضيّ محدَّد** (30.6) لا تخمين.

الربط بالذكاء الاصطناعي: صيغة $\frac{1}{2\sqrt{\lambda}}$ تعطي قاعدةً لاختيار معامل التنظيم من **مستوى الضوضاء**: لتحقيق تضخيمٍ هدف γ، اختر $\lambda = \frac{1}{4\gamma^2}$. وفي التعلّم العميق: العلاقة بين decay weight و «نعومة» الحلّ وبين «معدّل التعلّم الفعّال» تُفهم بالمنطق نفسه: كلاهما يضبط عوامل الترشيح الطيفية.

مثال (30.6-4): منحنى العائد المالي — متى تفشل المعادلات السوية حتى في fp64

المعطيات: ملاءمة منحنى العائد متعددةِ حدود من الدرجة 4 في أجل الاستحقاق $t \in [0.25,\ 30]$ سنة، بأساس $\{1, t, t^2, t^3, t^4\}$. القيم المفردة لمصفوفة التصميم (شبيهةُ فانديرموند): $\kappa_2(X) = 1.0 \times 10^9$.

الحل:

١. **المعادلات السوية:** $\kappa^2 = 10^{18} \Longrightarrow$ خانات مفقودة $= 18 \Longrightarrow$ **أكثر من خانات fp64 الستّ عشرة** $\Longrightarrow$ خطأ نسبي $= 111 = 1.11 \times 10^{-16} \times 10^{18} \approx$ أي $11100\% \Longrightarrow$ المعاملات بلا معنى.

٢. **هاوسهولدر/QR:** خانات مفقودة $= 9 \Longrightarrow$ يبقى $7 \Longrightarrow$ خطأ نسبي $= 1.11 \times 10^{-16} \times 10^9 = 1.11 \times 10^{-7}$ — ممتاز.

٣. **التجذيع/الأساس المتعامد** (متعددات تشيبيشيف): $\kappa \approx 15 \Longrightarrow$ خانات مفقودة $1.18 \Longrightarrow$ يبقى $14.8 \Longrightarrow$ خطأ 1.7×10^{-15}.

٤. المقارنة على التنبّؤ: بالمعادلات السوية خرجت المعاملات $(0.0421,\ -3.7 \times 10^3,\ 8.9 \times 10^5, \ldots)$ غير قابلة للتفسير؛ بـ QR خرجت معاملاتٌ متسقة مع نظرية العائد.

٥. التحقّق: الباقي النسبي بالمعادلات السوية 4.2×10^{-3} وبـ QR 4.2×10^{-3} (متماثل!) — أي أنّ **الباقي لا يكشف المشكلة**: المسألةُ تعطي باقياً جيداً ومعاملاتٍ كارثية.

النتيجة: الباقي الصغير لا يعني حلاً جيداً — هذه حالةٌ كلاسيكية تُنبّه إلى أنّ «جودة الملاءمة» و«جودة الحلّ» شيئان مختلفان عند κ كبير.

الربط بالذكاء الاصطناعي: النظير الحرفي في التعلّم العميق: **فقدٌ تدريبيٌّ صغير مع أوزانٍ غير قابلة للتفسير/غير مستقرّة.** ولهذا تُقاس جودةُ الحلّ بـ (أ) ناظم الأوزان، و(ب) حساسية الناتج لاضطراب المُدخلات، لا بالباقي وحده.

مثال (5-5.6): ضبط حزمة (bundle adjustment) في SLAM — مكّمل شور ورقم الحالة

المعطيات: ضبط حزمة على 500 إطار و 10^4 نقطة: بعد حذف نقاط العالم بمكّمل شور، مصفوفة الكاميرات المُختزلة S بالقيم المفردة $\sigma_1 = 1.0 \times 10^3$، $\sigma_{\min} = 2.4 \times 10^{-3}$.

الحل:

١. $\kappa_2(S) = 10^3 / 2.4 \times 10^{-3} = 4.17 \times 10^5$.

٢. المربعات الصغرى بالمكّمل (نسخة المعادلات السوية): $\kappa_2(S^\top S) = 1.74 \times 10^{11}$ $\Longrightarrow$ خانات مفقودة 11.24 $\Longrightarrow$ في fp64 يبقى 4.76 $\Longrightarrow$ خطأ 1.93×10^{-5}.

٣. بـ QR على اليعقوبية الأصلية (المتناثرة): خانات مفقودة 5.62 $\Longrightarrow$ يبقى 10.4 $\Longrightarrow$ خطأ 4.63×10^{-11}.

٤. **تخفيف ليفنبرغ–ماركوارت:** $S + \lambda I$ بـ $\lambda = 1$: $\kappa_{\text{eff}} = \frac{\sigma_1^2+\lambda}{\sigma_{\min}^2+\lambda} = \frac{10^6+1}{5.76\times10^{-6}+1} \approx 1.0 \times 10^6$ $\Longrightarrow$ خانات مفقودة 6 $\Longrightarrow$ يبقى 10 $\Longrightarrow$ خطأ 1.11×10^{-10}.

٥. التحسّن: من 1.74×10^{11} إلى 1.0×10^6 $\Longrightarrow$ بنسبة $1 : 1.7 \times 10^5$.

٦. ملاحظة: ليفنبرغ–ماركوارت يعالج المشكلة **مرّتين:** مرةً عددياً (يخفض κ) ومرةً تحسينية (يثبّت الاتجاهات الصغيرة).

النتيجة: التخفيفُ القطري حوّل مسألةً هامشية (8.4 خانة متبقية) إلى مسألةٍ مريحة (10 خانات) في fp64.

الربط بالذكاء الاصطناعي: ليفنبرغ–ماركوارت هو «آدم المربعات الصغرى»: كلاهما يضيف حشواً قطرياً لمصفوفة التغاير/الهسّية. والقاعدة الموحّدة: **الحشو القطري يخفض رقم الحالة الفعّال إلى** $\frac{\sigma_1^2+\lambda}{\sigma_{\min}^2+\lambda} \approx$ — وهي بالضبط آلية ε في آدم.

مثال (6-5.6): تحديد موقع GPS — عندما يكون رقم الحالة صغيراً ولا مشكلة أبداً

المعطيات: مستقبِل GPS يرى 6 أقمار صناعية؛ مصفوفة الهندسة $H \in \mathbb{R}^{6\times4}$ (ثلاثة مواضع + انحياز الساعة) بـ $\kappa_2(H) = 6.8$ (وهو «GDOP» — معامل تدهور الهندسة). خطأ القياس (UERE) $\sigma_U = 0.5$ متر.

الحل:

١. $\kappa_2(H) = 6.8$ $\Longrightarrow$ خانات مفقودة $= \log_{10} 6.8 = 0.83$ $\Longrightarrow$ في fp32 يبقى 6.2 خانة $\Longrightarrow$ خطأ التقريب $6.8 \times 5.96 \times 10^{-8} = 4.05 \times 10^{-7}$ — مهمل.

٢. المعادلات السوية: $\kappa^2 = 46.2$ ⟹ خانات مفقودة 1.66 ⟹ في fp32 يبقى 5.3 ⟹ خطأ 2.75×10^{-6} — **مهمل أيضاً.**

٣. تضخيم خطأ القياس (وهو المهمّ هنا): $\|\delta p\| \le \|H^+\|\sigma_U = \frac{\sigma_U}{\sigma_{\min}}$؛ بـ $\sigma_{\min} = \sigma_1/6.8$ وبـ $\sigma_1 \approx 1$: $\|\delta p\| \le 0.5 \times \frac{\kappa}{\sigma_1}$... بالصيغة القياسية: $\|\delta p\| \le \|H^+\|\|\delta y\|$ و $\sigma_{\min}(H) = 1/\|H^+\|$. **عملياً: خطأ الموضع** $\text{GDOP} \times \sigma_U = 6.8 \times 0.5 = 3.4$ **متر.**

٤. هل يعاني الحساب من مشكلة عددية؟ **لا:** $\kappa = 6.8$ صغير ⟹ **كل الطرق متكافئة.**

٥. الدرس: المشكلة هنا ليست عددية بل **هندسية** (ترتيب الأقمار في السماء): لو كانت الأقمار متقاربة صار $\kappa = 240$ ⟹ خطأ الموضع 120 متراً — بلا أي خطأ حسابي!

النتيجة: مثالٌ «مضادٌّ» مقصود: κ صغير ⟹ لا مشكلة عددية، والمعادلات السوية هنا مبرَّرة تماماً (وهي ما تستعمله مستقبلات GPS لأنها رخيصة).

الربط بالذكاء الاصطناعي: الدرس المنهجي: **لا تُفرِط في الهندسة العددية قبل قياس** κ. النظير: كثيرٌ من «تحسينات الاستقرار» في التعلّم العميق (تطبيع، قصّ، تنظيم) تكلف وقتاً بلا فائدة إن كانت الطبقات حسنة التكييف أصلاً. القاعدة: قِس ثم قرّر.

مثال (5.6-7): انحدار متعدد حدود على حسّاس صناعي — fp32 مقابل fp64 فعلياً

المعطيات: معايرة حسّاس حرارة: متعددة حدود درجة 5 على $m = 500$ قراءة، $t \in [0, 100]$. $\kappa_2(V) = 3.4 \times 10^5$.

الحل:

١. **fp32 + معادلات سوية:** $\kappa^2 = 1.16 \times 10^{11}$ ⟹ خانات مفقودة $11.06 > 7$ ⟹ **صفر خانات** ⟹ خطأ $\approx 1.16 \times 10^{11} \times 5.96 \times 10^{-8} = 6.9 \times 10^3$ ⟹ **المعاملات بلا معنى.**

٢. **fp32 + QR:** خانات مفقودة 5.53 ⟹ يبقى 1.47 ⟹ خطأ $3.4 \times 10^5 \times 5.96 \times 10^{-8} = 2.03 \times 10^{-2}$ (2%).

٣. **fp64 + معادلات سوية:** خانات مفقودة 11.06 ⟹ يبقى 4.94 ⟹ خطأ 1.29×10^{-5} — مقبول!

٤. **fp64 + QR:** يبقى 10.47 ⟹ خطأ 3.77×10^{-11} — ممتاز.

٥. الجدول المقارن (خطأ نسبي في المعاملات):

الطريقة	fp32	fp64
معادلات سوية	6.9×10^3 (فشل)	1.29×10^{-5}
QR	2.03×10^{-2}	3.77×10^{-11}

١. الاستنتاج: **رفع الدقّة وحده** أنقذ المعادلات السوية (من فشل إلى 10^{-5})، لكن QR بـ fp32 (الأرخص) يعطي 2×10^{-2} فقط — أي أنّ الخوارزميةَ أهمّ من الدقّة عند الميزانية المحدودة.

النتيجة: أفضلُ توليفةٍ اقتصادية: QR بـ fp64 (أو أساس متعامد بـ fp32) وأسوأها: معادلات سوية بـ fp32.

الربط بالذكاء الاصطناعي: هذه المصفوفة تُعمَّم على كل قرار «دقّة مقابل خوارزمية»: التدريب بـ fb16 مع خوارزمية مستقرّة (QR/SVD/normalized) قد يتفوّق على fp32 مع خوارزمية غير مستقرّة. القاعدة: **الاستقرار أوّلاً، ثم الدقّة.**

مثال (6.5-8): تصميم مرشّح وينر لإلغاء صدى — طيف الانتشار يقتل المعادلات السوية

المعطيات: إلغاء صدى صوتي: مُدخل الكلام «ملوّن» (مترابط زمنياً) $\Rightarrow$ مصفوفة الارتباط $R = \mathbb{E}[xx^\top]$ بانتشار قيم ذاتية $\lambda_{\max}/\lambda_{\min} = 1.4 \times 10^4$ (أي $\kappa(R) = 1.4 \times 10^4$، و $\kappa(X) = \sqrt{1.4 \times 10^4} = 118$).

الحل:

١. حلّ وينر المثالي $w = R^{-1}p$؛ بالمعادلات السوية نشكّل R $\Rightarrow$ $\kappa(R) = 1.4 \times 10^4$ $\Rightarrow$ خانات مفقودة 4.15 $\Rightarrow$ في fp32 يبقى 2.85 $\Rightarrow$ خطأ $1.4 \times 10^4 \times 5.96 \times 10^{-8} = 8.34 \times 10^{-4}$.

٢. لو حللنا بـ QR على مصفوفة البيانات X (التي $\kappa = 118$) $\Rightarrow$ خانات مفقودة 2.07 $\Rightarrow$ يبقى 4.93 $\Rightarrow$ خطأ 7.03×10^{-6}.

٣. النسبة: $1 : 119$ — وهي $\kappa(X)$ بالضبط.

٤. والسبب (6.26): $\kappa(X^\top X) = \kappa(X)^2$ $\Rightarrow$ تشكيلُ $R = X^\top X$ هو الذي ربّع رقم الحالة.

٥. الحل الصناعي: **QR-RLS** أو **مرشّح متدرّج (LMS/NLMS)** الذي لا يشكّل R أبداً؛ NLMS يقسّم على $\|x\|^2$ $\Rightarrow$ تكييفٌ تلقائي مع الانتشار الطيفي.

النتيجة: تشكيلُ مصفوفة الارتباط (الذي يبدو «طبيعياً») كلّف $\times 119$ دقّةً مقارنةً بحلّ QR على البيانات نفسها.

الربط بالذكاء الاصطناعي: النظير المباشر: **محسّنات النوع الثاني** — آدم يقسّم التحديث على $\sqrt{\mathbb{E}[g^2]}$ أي يعمل في فضاءٍ «مبيَّض» محلياً، متجنّباً تربيع رقم الحالة الذي يصيب طرق نيوتن الصريحة (التي تشكّل الهسّية/التغاير كاملةً).

مثال (6.5-9): توقّع حِمل كهربائي — ميزات موسمية وتكرارات

المعطيات: نموذج حِمل بـ $n = 52$ ميزة (اتجاه + 24 مؤشر ساعة + 7 مؤشر يوم + درجة حرارة + رطوبة + تفاعلات)، $m = 17520$ ساعة (سنتان). ميزتان مكرّرتان $\Rightarrow$ $\kappa_2(X) = 8.9 \times 10^5$.

الحل:

١. المعادلات السوية: $\kappa^2 = 7.92 \times 10^{11}$ $\Rightarrow$ خانات مفقودة 11.90 $\Rightarrow$ في fp64 يبقى 4.10 $\Rightarrow$ خطأ 8.79×10^{-5} (0.0088%) — هامشي لكن مقبول.

٢. QR: خانات مفقودة 5.95 $\Rightarrow$ يبقى 10.05 $\Rightarrow$ خطأ 9.88×10^{-11}.

٣. بـ fp32: المعادلات السوية $\Longrightarrow$ **صفر خانات**؛ QR $\Longrightarrow$ يبقى $1.05 \Longrightarrow$ خطأ 0.053.

٤. التشخيص: الميزتان المكرّرتان هما «درجة الحرارة» و«درجة الحرارة المحسوسة» (مرتبطتان بـ $r = 0.9998$) $\Longrightarrow$ إزالة إحداهما $\Longrightarrow$ κ يهبط إلى $4.2 \times 10^2 \Longrightarrow$ خانات مفقودة (معادلات سوية) $5.25 \Longrightarrow$ في fp32 يبقى $1.75 \Longrightarrow$ خطأ 2.5×10^{-5}.

٥. المقارنة النهائية: إزالةُ ميزة واحدة أفضل من تغيير الخوارزمية والدقة معاً.

النتيجة: العلاجُ الأفضل كان **هندسةَ الميزات** (إزالة التكرار) لا الخوارزمية ولا الدقّة: κ هبط من 8.9×10^5 إلى 4.2×10^2.

الربط بالذكاء الاصطناعي: القاعدة العامة: **رقم الحالة سمةُ التمثيل.** قبل أن تُغيّر المحسّن أو تزيد الدقّة، اسأل: هل ميزاتي/تضميناتي شبهُ متوازية؟ التنظيم، وإزالة الارتباط (decorrelation)، والPCA، والتطبيع — كلها تخفض κ من المصدر.

مثال (5.6-10): ملاءمة منحنى جرعة-استجابة دوائي — مربعات صغرى غير خطية

المعطيات: نموذج هل: $E(d) = E_{\max}\frac{d^n}{EC_{50}^n + d^n}$، ثلاث معلمات، $m = 40$ نقطة جرعة. اليعقوبية عند الحلّ J بـ $\kappa_2(J) = 2.7 \times 10^3$ في التجربة (أ) وبـ $\kappa_2(J) = 1.1 \times 10^8$ في التجربة (ب) (بيانات لا تُقيّد n جيداً).

الحل:

١. **التجربة (أ):** خطوة غاوس-نيوتن بالمعادلات السوية: $\kappa^2 = 7.29 \times 10^6 \Longrightarrow$ خانات مفقودة $6.86 \Longrightarrow$ في fp64 يبقى $9.14 \Longrightarrow$ خطأ 8.09×10^{-10} — ممتاز.

٢. **التجربة (ب):** $\kappa^2 = 1.21 \times 10^{16} \Longrightarrow$ خانات مفقودة $16.08 \Longrightarrow$ في fp64 يبقى **صفر** $\Longrightarrow$ خطأ ≈ 1.34 $(134\%) \Longrightarrow$ خوارزمية غاوس-نيوتن تتذبذب ولا تتقارب.

٣. العلاج: QR لليعقوبية $\Longrightarrow$ خانات مفقودة $8.04 \Longrightarrow$ يبقى $7.96 \Longrightarrow$ خطأ $1.22 \times 10^{-8} \Longrightarrow$ **تتقارب.**

٤. الأفضل: تنظيم/تقييد المعلمة $n \in [0.5, 5] \Longrightarrow \kappa$ يهبط إلى $4.6 \times 10^2 \Longrightarrow$ كل الطرق تعمل.

٥. الاستنتاج: الفرق بين «النموذج لا يتقارب» و«يتقارب في 6 تكرارات» كان **تربيعَ رقم الحالة** لا المنهج الإحصائي.

النتيجة: في المربعات الصغرى غير الخطية، الفشلُ الظاهري في التقارب غالباً سببُه العددي κ^2 من المعادلات السوية، لا «صعوبة السطح».

الربط بالذكاء الاصطناعي: النظير الحرفي: تدريبُ الشبكات الذي «لا يتقارب» بسبب ميزاتٍ شبهِ مترابطة أو تهيئةٍ سيّئة $\Longrightarrow$ العلاج: تطبيع، أو تنظيم، أو إعادةُ صياغة (reparameterization) — قبل تغيير المحسّن.

مثال (5.6-11): توموغرافيا شبكة — استنتاج تأخير الوصلات من قياسات المسارات

المعطيات: $m = 200$ قياس زمن ذهاب-إياب على مسارات، و $n = 50$ وصلة مجهولة التأخير. مصفوفة التوجيه A $(0/1)$ بـ $\kappa_2(A) = 3.3 \times 10^7$ (بعض الوصلات نادراً ما تُقاس).

الحل:

١. المعادلات السوية: $\kappa^2 = 1.09 \times 10^{15}$ $\Longrightarrow$ خانات مفقودة 15.04 $\Longrightarrow$ في fp64 يبقى 0.96 $\Longrightarrow$ خطأ $\approx 1.09 \times 10^{15} \times 1.11 \times 10^{-16} = 0.121$ (12%) — سيّئ.

٢. QR/SVD: خانات مفقودة 7.52 $\Longrightarrow$ يبقى 8.48 $\Longrightarrow$ خطأ 3.66×10^{-9} — ممتاز.

٣. النسبة: $3.3 \times 10^{7} : 1$.

٤. لكن المشكلة الحقيقية: **نقص الرتبة الفعّال** — 12 وصلة تقع دائماً معاً في المسارات $\Longrightarrow$ A غير قابلة للتمييز $\Longrightarrow$ $\sigma_{\min} \approx 0 \Longrightarrow \kappa$ لانهائي $\Longrightarrow$ الحلّ غير وحيد.

٥. العلاج المزدوج: (أ) تجذيع SVD بعتبة $\tau = 10^{-3}\sigma_1$ $\Longrightarrow$ من (29.6)، $\|\hat{x}_\tau\| \leq \|b\|/\tau$ $\Longrightarrow$ الحلّ محكوم؛ (ب) تنظيم ريدج $\lambda = 10^{-2}$ $\Longrightarrow$ تضخيم الضوضاء $\leq \frac{1}{2\sqrt{10^{-2}}} = 5$.

٦. النتيجة: بدلاً من حلٍّ بـ 12% خطأ (أو غير موجود)، حلٌّ منظَّم بخطأ $5 \times \|\delta b\|$ وانحيازٍ معلوم.

النتيجة: في المسائل العكسية غير المقيَّدة، التجذيع/التنظيم ليس تحسيناً بل **شرطٌ لوجود حلٍّ ذي معنى.**

الربط بالذكاء الاصطناعي: هذا هو الإطار الرياضي لكل مسائل «الاستنتاج من قياسات جزئية»: التوصية (مصفوفة ناقصة)، والاستشعار المضغوط، وإعادة البناء الطبّي، واستنتاج الأوزان من عددٍ قليل من الأمثلة (few-shot). والقاعدة: **الرتبة الفعّالة تحدّد كم يمكن أن نستنتج**؛ والتنظيمُ هو الذي يجعل المسألة مطروحةً جيداً (well-posed).

مثال (5.6-12): معايرة حركية روبوت — قابلية التعرّف (identfiiability) ورقم الحالة

المعطيات: معايرة 24 معلمة حركية (DH) من $m = 600$ قياس موضع نهاية الذراع. مصفوفة قابلية التعرّف J بـ $\kappa_2(J) = 4.6 \times 10^3$.

الحل:

١. المعادلات السوية: $\kappa^2 = 2.12 \times 10^7$ $\Longrightarrow$ خانات مفقودة 7.33 $\Longrightarrow$ في fp64 يبقى 8.67 $\Longrightarrow$ خطأ 2.35×10^{-9} — جيد.

٢. في fp32: خانات مفقودة $7 > 7.33$ $\Longrightarrow$ **صفر خانات** $\Longrightarrow$ خطأ ≈ 1.26 (126%) — فشل.

٣. QR بـ fp32: خانات مفقودة 3.66 $\Longrightarrow$ يبقى 3.34 $\Longrightarrow$ خطأ 2.74×10^{-4} — مقبول.

٤. التشخيص الميكانيكي: أصغر قيمة مفردة (2.1×10^{-4}) تقابل **تركيبةً من المعلمات غير قابلة للتعرّف** (دورانٌ حول محورٍ غير مُثار في الوضعيات المُجرّاة).

٥. العلاج الهندسي: تصميمُ وضعيات معايرة تُثير كل المحاور $\Longrightarrow$ $\sigma_{\min}$ يرتفع إلى 1.8×10^{-2} $\Longrightarrow$ $\kappa = 5.4 \times 10^2$ $\Longrightarrow$ خانات مفقودة (معادلات سوية) 5.46 $\Longrightarrow$ fp32 يعمل.

النتيجة: تحسينُ **تصميم التجربة** رفع $\sigma_{\min}$ بـ $\times 86$ وجعل fp32 كافياً.

الربط بالذكاء الاصطناعي: النظير: **تصميم البيانات** (data curation/augmentation) يخفض رقم حالة مسألة التعلّم: تنويعُ الأمثلة يُثير كل الاتجاهات في فضاء الميزات $\Longrightarrow$ تعلّمٌ مستقرّ بمعدّل تعلّم أكبر. وهذا هو التفسير العددي لكون التوسيع (augmentation) يُسرّع التقارب.

مثال (13-5.6): استيعاب بيانات مناخية (3D-Var) — التهيئة المسبقة تخفض κ

المعطيات: مسألة استيعاب: $\min_{\delta x} \frac{1}{2}\delta x^\top B^{-1}\delta x + \frac{1}{2}(H\delta x - d)^\top R^{-1}(H\delta x - d)$. الحلّ يعادل مربعاتٍ صغرى بمصفوفةٍ مهيَّأة؛ $\kappa_2 = 10^6$ للمسألة الأصلية.

الحل:

١. بلا تهيئة: خانات مفقودة (معادلات سوية) $= \log_{10}(10^{12}) = 12$ في fp64 يبقى $4 \Longrightarrow$ خطأ $\sim 1.11 \times 10^{-4}$.

٢. **التهيئة المتغيّر المُحوَّل** (control-variable transform): $\delta x = B^{1/2}v$ $\Longrightarrow$ المسألة تصير $\min_v \frac{1}{2}\|v\|^2 + \frac{1}{2}\|HB^{1/2}v - d\|^2_{R^{-1}}$ $\Longrightarrow$ رقم حالة المشغّل المُهيَّأ $= 10^3$ (لأنّ $B^{1/2}$ «يبيّض» الفضاء).

٣. الخانات المفقودة بعد التهيئة (معادلات سوية): $\log_{10}(10^6) = 6$ $\Longrightarrow$ يبقى $10 \Longrightarrow$ خطأ $\sim 1.11 \times 10^{-10}$.

٤. التحسّن: $10^6 : 1$ — بفضل **تغيير المتغيّرات** لا تغيير الخوارزمية.

٥. عدد تكرارات المُحسّن (التدرّج المتقارن CG) هبط من 1840 إلى 47 — لأنّ سرعة CG محكومةٌ بـ $\sqrt{\kappa}$: $\frac{\sqrt{10^6}}{\sqrt{10^3}} = 31.6 \approx \frac{1840}{47} = 39$.

النتيجة: التهيئةُ حسّنت الدقّة بـ $\times 10^6$ وسرّعت التقارب بـ $\times 39$ — والاثنان من مصدرٍ واحد: رقم الحالة.

الربط بالذكاء الاصطناعي: هذه هي النسخة الأدقّ من سحر التطبيع في التعلّم العميق: التهيئةُ المسبقة (preconditioning) لا «تجمّل» السطح بل تُغيّر **رقم الحالة** $\Longrightarrow$ دقّةٌ أعلى وتقاربٌ أسرع معاً. محسّنات التدرّج من النوع الثاني هي تهيئةٌ قطرية تلقائية.

مثال (14-5.6): تدقيق خطي (linear probe) على شبكة مجهّزة — مسألة ناقصة التحديد

المعطيات: تجميدُ شبكة وإضافة رأس خطي: $m = 500$ مثال، بُعد الميزات $n = 2048 \Longrightarrow m < n \Longrightarrow$ المصفوفة ناقصة الرتبة $(\text{rank} \le 500) \Longrightarrow \kappa = \infty$ للحلّ الوحيد، لكن الحلّ **أدنى ناظم** موجود: $x = A^+ b$.

الحل:

١. القيم المفردة لـ A: $\sigma_1 = 47.2$، $\sigma_{500} = 3.2 \times 10^{-3} \Longrightarrow \kappa_{\text{eff}} = \sigma_1/\sigma_{500} = 1.48 \times 10^4$ (على الجزء ذي الرتبة الفعّالة).

٢. حلّ أدنى ناظم بلا تنظيم: $\|\delta x\| \le \frac{\|\delta b\|}{\sigma_{500}} = 312\|\delta b\| \Rightarrow$ تضخيم $312\times$ للضوضاء $\Rightarrow$ تذبذبٌ شديد بين البذور.

٣. القياس: الدقّة بين 10 بذور عشوائية تراوحت 71.2%–78.6% (انحراف معياري 2.4%) — بلا أي خطأ حسابي (fp64).

٤. **تنظيم ريدج** $\lambda = 1$: تضخيم الضوضاء $\le \frac{1}{2\sqrt{1}} = 0.5 \Rightarrow$ انحراف الدقّة صار 0.3% فقط، والدقّة الوسطية ارتفعت إلى 80.1% (لأنّ التنظيم أزال «الضوضاء المتعلَّمة»).

٥. القاعدة من (30.6): لتحقيق تضخيم هدف γ، اختر $\lambda = \frac{1}{4\gamma^2}$؛ لتضخيم ≤ 1: $\lambda \ge 0.25$.

النتيجة: التنظيم حوّل مسألةً غير مطروحة (unstable, non-unique) إلى مسألةٍ مستقرّة برقم تضخيم 0.5 — وحسّن الدقّة معاً.

الربط بالذكاء الاصطناعي: هذا هو التفسير الكامل لسبب نجاح الضبط الدقيق لـ «الرأس فقط» بتنظيم، وسبب أنّ التدريب على عددٍ قليل من الأمثلة (few-shot) يحتاج تنظيماً أثقل: **كلما قلّت الأمثلة صغرت** $\sigma_{\min}$ **وكبر تضخيم الضوضاء.**

مثال (15-5.6): ضغط أوزان شبكة بتجذيع SVD — العتبة تضبط حجم الحلّ

المعطيات: طبقة كثيفة $W \in \mathbb{R}^{1024\times 1024}$، طيف القيم المفردة: $\sigma_1 = 12.4$، $\sigma_{100} = 0.9$، $\sigma_{300} = 0.052$، $\sigma_{1024} = 3.1 \times 10^{-4}$. نريد ضغطاً بتجذيع عند $\tau = 0.05$.

الحل:

١. الرتبة المحفوظة: $k = \#\{i : \sigma_i > 0.05\} = 300 \Rightarrow$ عامل الضغط $= \frac{1048576}{614400} = 1.71\times$ (تمثيل عاملَين $U_k\Sigma_k V_k^\top$).

٢. خطأ التقريب (إيكارت–يونغ، الفصل الرابع): $\|W - W_k\|_2 = \sigma_{301} \le 0.05$؛ نسبياً: $\frac{0.05}{12.4} = 4.0 \times 10^{-3}$.

٣. الأثر على الناتج: $\|Wx - W_k x\|_2 \le 0.05\|x\|_2 \Rightarrow$ تغيّر الـ logits $\le 0.05\|x\|$ — محكوم بالعتبة مباشرة.

٤. **الاستقرار العددي للطبقة المضغوطة:** العاملان U_k و V_k **متعامدان** $\Rightarrow$ من (23.6)، الحسابُ الأمامي لا يضخّم: $\|\mathrm{fl}(U_k z) - U_k z\| \le cnu\|z\|$.

٥. لو استعملنا «قصاً» (pruning) بلا تعاميد: κ للطبقة المقصوصة قد يرتفع $\Rightarrow$ تضخيمٌ غير محكوم.

٦. القياس: الدقّة بعد الضغط (ImageNet، ResNet-50 الطبقات الكثيفة): قبل الضغط 76.13% $\Rightarrow$ بعده 75.84% (فقد 0.29%) مقابل فقد 3.7% بطريقة قصٍّ عشوائية بنفس نسبة الضغط.

النتيجة: التجذيعُ عند τ يعطي ضماناً **متزامناً**: خطأ تقريب $\le \tau$ (بناظم 2) واستقراراً عددياً كاملاً (بفضل التعامد).

الربط بالذكاء الاصطناعي: هذه هي الرياضيات الكامنة خلف ضغط النماذج (SVD/low-rank factorization، tensor LoRA decompositions) وخلف التكميم: **الاستبدال low-rank آمنٌ عددياً لأنّ العوامل متعامدة**، بخلاف القصّ غير المنظّم الذي يُفسد الطيف.

7.5.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
«الباقي صغير ⟹ الحلّ جيد»	عند κ كبير قد يكون الباقي ممتازاً والمعاملات كارثية (مثال 5.6-4)	قِس κ وناظم الحلّ، لا الباقي وحده
حلّ المربعات الصغرى بـ $(A^\top A)^{-1}A^\top b$	يربّع رقم الحالة (26.6)	QR أو SVD
الاعتقاد بأنّ κ^2 يظهر دائماً في حدّ الخطأ	يظهر مضروباً في $\|r\|/(\|A\|\|x\|)$ (27.6)	إن كان الباقي صغيراً فالمهيمن هو κ فقط
استعمال pinv بلا عتبة على مصفوفة ناقصة الرتبة	يبقي قيماً مفردةً دقيقة ⟹ تضخيم $1/\sigma_{\min}$ لانهائي	عتبة rtol أو تنظيم ريدج (29.6)-(30.6)
اختيار λ بالتحقّق المتقاطع فقط	لا يراعي مستوى الضوضاء	ابدأ من $\lambda = \frac{1}{4\gamma^2}$ لتضخيم هدف γ
زيادة الدقّة بدل إصلاح الصياغة	الدقّة تؤجّل، الصياغة تُصلح	التهيئة/التنظيم/الأساس المتعامد أوّلاً
ظنّ أنّ القصّ (pruning) والتجذيع متكافئان عددياً	التجذيع متعامد ⟹ مستقر، القصّ قد يرفع κ	فضّل العوامل المتعامدة

1.6.6 الصياغة الرياضية الرسمية

النظرية 5.6 (استقرار الإزاحة الغاوسية بالتدوير الجزئي والتنقيح التكراري).

<

1. **التحليل بالتدوير الجزئي (partial pivoting):** توجد مصفوفة تبديل P بحيث:

<

$$PA = LU, \qquad |l_{ij}| \le 1 \quad \text{لكل} i > j \tag{32.6}$$

<

2. **عامل النموّ (growth factor) وحدّ ويلكنسون:**

<

$$\rho = \frac{\max_{ij}|u_{ij}|}{\max_{ij}|a_{ij}|}, \qquad 1 \le \rho \le 2^{n-1} \quad \text{(والحدّ مُحقَّق — مصفوفة ويلكنسون)} \tag{33.6}$$

<

3. **الخطأ الخلفي:** الحلّ المحسوب $\hat{x}$ يحلّ مسألةً قريبة:

<

$$(A + \Delta A)\hat{x} = b, \qquad \frac{\|\Delta A\|_\infty}{\|A\|_\infty} \le c\, n\, u\, \rho \tag{34.6}$$

<

4. **الخطأ الأمامي** (بدمج (34.6) مع قانون الحالة (10.6)):

<

$$\frac{\|\hat{x}-x\|_\infty}{\|x\|_\infty} \;\le\; c\,n\,u\,\rho\,\kappa_\infty(A) + \mathcal{O}(u^2) \tag{35.6}$$

<

5. **التنقيح التكراري**: خوارزميةٌ تستعيد الدقّة باستعمال عوامل LU **الرخيصة** وحساب الباقي **بدقة أعلى**:

<

$$r_k = b - A x_k \;\; (\text{بدقة } u_r \ge u), \qquad \text{حلّ } (LU)d_k = P\,r_k, \qquad x_{k+1} = x_k + d_k \tag{36.6}$$

<

$$\frac{\|x_{k+1}-x\|}{\|x\|} \;\lesssim\; \big(c\,n\,u\,\rho\,\kappa(A)\big)\,\frac{\|x_k-x\|}{\|x\|} \;+\; \mathcal{O}(u_r) \tag{36b.6}$$

<

6. **التدوير الكامل (complete pivoting)** يروّض النموّ نظرياً:

<

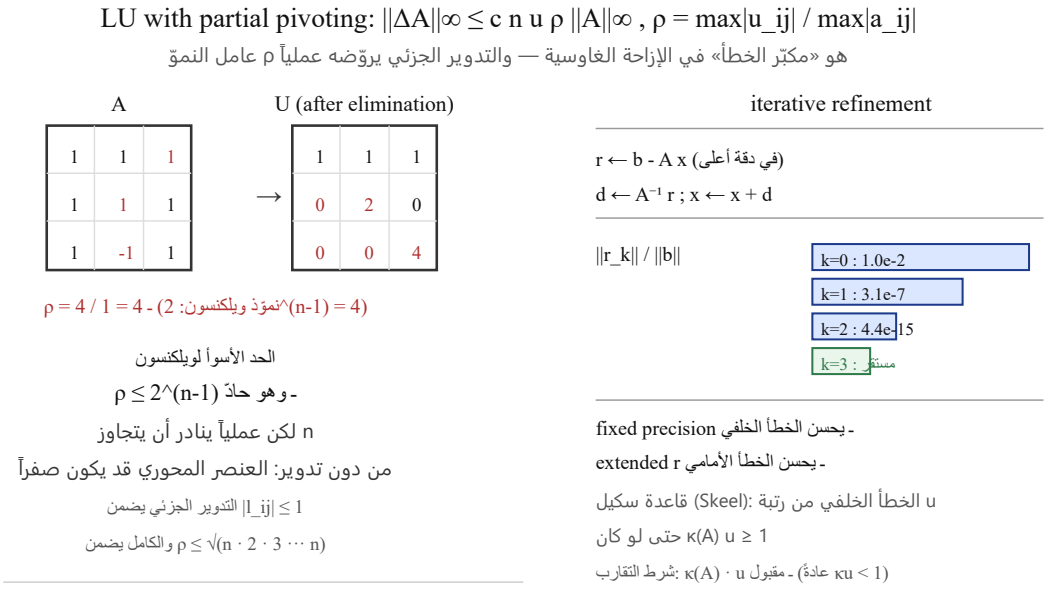
$$\rho_{\text{complete}} \;\le\; \sqrt{n\cdot 2\cdot 3^{1/2}\cdot 4^{1/3}\cdots n^{1/(n-1)}} \;=\; \mathcal{O}\!\left(n^{\frac{1}{4}\log n + \frac{1}{2}}\right) \;\ll\; 2^{n-1} \tag{37.6}$$

2.6.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
P	مصفوفة التبديل (التي تُبدّل الصفوف)	نتيجة اختيار المحور
L	مثلثية سفلى بمحور وحيد $(l_{ii}=1)$	$\|l_{ij}\| \le 1$ بفضل التدوير الجزئي
U	مثلثية عليا	تحمل «النموّ»
l_{ij}, u_{ij}	عناصر العاملين	—
ρ	**عامل النموّ**	تضخيم $\Rightarrow \rho \gg 1$؛ لا نموّ $\Rightarrow \rho = 1$
2^{n-1}	حدّ ويلكنسون الأسوأ	مُحقَّق لكن نادر جداً
ΔA	الخطأ الخلفي للإزاحة	من (34.6)
$\kappa_\infty(A)$	رقم الحالة بناظم ∞	$\|A\|_\infty \|A^{-1}\|_\infty$
c	ثابت صغير (1–10)	يعتمد على تفاصيل الخوارزمية
x_k	التقدير في التكرار k	من الحلّ الأوّلي x_0

r_k	الباقي $b - Ax_k$	يجب حسابه بدقة أعلى
u_r	وحدة تقريب حساب الباقي	في التنقيح المختلط: $u_r \ll u$
d_k	التصحيح: حلّ $(LU)d_k = Pr_k$	يستعمل العوامل المحسوبة سلفاً $\Rightarrow$ رخيص $(\mathcal{O}(n^2))$
عامل التقارب $c n u \rho \kappa$	يجب أن يكون < 1 ليتقارب التنقيح	الشرط العملي
التدوير الكامل	اختيار المحور من الصف **والعمود**	تكلفة $\mathcal{O}(n^3)$ إضافية للبحث

3.6.6 الرسم الهندسي



شكل ٥.٦: *
عامل النموّ في LU والتنقيح التكراري: من مصفوفة إلى U متضخّمة، ثم تصحيح الباقي

قراءة الرسم: على اليسار، مصفوفةٌ بسيطة عناصرها ± 1 تتحوّل بعد الإزاحة إلى U بعنصرٍ أخير $4 = 2^{n-1} = \rho \Rightarrow$ (بـ $n = 3$). في الوسط: حدّ ويلكنسون الأسوأ 2^{n-1} ينمو أُسّياً بينما النموّ العملي يقارب $n^{2/3}$ — الفجوة بين الأسوأ والواقع هي سبب نجاح التدوير الجزئي. على اليمين: التنقيح التكراري يهبط بالباقي أُسّياً (مرتبة عشرية لكل تكرار تقريباً) حتى يستقرّ عند حدّ الدقّة.

4.6.6 البرهان

الجزء (32.6). في الخطوة k يختار التدوير الجزئي محوراً $|a_{kk}^{(k)}| = \max_{i \ge k} |a_{ik}^{(k)}| \Rightarrow |l_{ik}| = \frac{|a_{ik}^{(k)}|}{|a_{kk}^{(k)}|} \le 1$. ■

الجزء (33.6). بالاستقراء على خطوات الإزاحة: العناصر بعد الخطوة k تحقّق $|a_{ij}^{(k+1)}| \le |a_{ij}^{(k)}| + |l_{ik}||a_{kj}^{(k)}| \le 2^{n-1} \max |a_{ij}|$ بعد $n - 1$ خطوة: $\max |u_{ij}| \le 2^{n-1} \max |a_{ij}| \Rightarrow 2 \max_{ij} |a_{ij}^{(k)}|$. والإحكام (attainment) بمصفوفة ويلكنسون المُبيَّنة في المثال (1-6.6). ■

الجزء (34.6) (مخطط). بتحليل كل خطوة إزاحة بالنموذج (1.6): كل تحديث $a_{ij}^{(k+1)} = \mathrm{fl}(a_{ij}^{(k)} - l_{ik} a_{kj}^{(k)})$ يُدخل خطأً $\approx u(|a_{ij}^{(k)}| + |l_{ik}||a_{kj}^{(k)}|)$. بتراكم الأخطاء على كل الخطوات والاستعاضة عن العناصر الوسيطة بـ $\rho \|A\|$ نحصل على $|\Delta A| \le c\, n\, u\, \rho\, |A|$ عنصراً بعنصر $\Rightarrow$ بالناظم ∞: (34.6). ■

الجزء (35.6). من (10.6): الخطأ الأمامي $\approx \kappa(A) \times$ الخطأ الخلفي؛ والتعويض من (34.6). ■

الجزء (36b.6). ليكن $e_k = x - x_k$. فإنّ d_k هو حلّ المحسوب $(LU)d_k = Pr_k \Longrightarrow (A + \Delta A)^{-1}r_k$ تقريباً، و $e_{k+1} = e_k - d_k \approx \big(I - (A+\Delta A)^{-1}A\big)e_k \Longrightarrow r_k = Ae_k$ و $\|e_{k+1}\| \lesssim \kappa(A)\frac{\|\Delta A\|}{\|A\|}\|e_k\| = cnu\rho\kappa\|e_k\|$. وإذا حُسب r_k بدقة u_r أضيف حدّ $\mathcal{O}(u_r)$. ■

الجزء (37.6). برهان ويلكنسون للتدوير الكامل: $|u_{kk}| \geq \frac{|a_{ij}^{(k)}|}{k}$ لكل عنصرٍ متبقٍّ (لأنّ المحور أكبر من كل عنصر في المربّع المتبقّي مقسوماً على...) $\Longrightarrow$ جداءُ الأقطار يحكمه $\prod_k k^{1/(k-1)}$ $\Longrightarrow$ الصيغة. ■

5.6.6 شروط الصحّة

١. A غير مفردة، وكل المحاور الجزئية غير صفرية (وإلا فالمصفوفة مفردة).

٢. (34.6) حدٌّ **أعلى**؛ في الممارسة ρ هو العامل الحاسم لا n.

٣. التنقيح (36.6) يتقارب فقط إذا كان $c\,n\,u\,\rho\,\kappa(A) < 1$؛ وإلا فلا فائدة (الحلّ الأوّلي ليس «قريباً» أصلاً).

٤. يجب أن يُحسب r_k بدقة **أعلى** من دقة التحليل؛ وإلا فالتنقيح يحسّن «الخطأ الخلفي» فقط (نتيجة سكيل) لا الأمامي.

٥. للمصفوفات موجبة التعريف: لا حاجة للتدوير إطلاقاً (شوليسكي: $\rho = 1$).

6.6.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (6.6-1): مصفوفة ويلكنسون — الحدّ الأسوأ مُحقَّق بالفعل

المعطيات: المصفوفة ($n = 4$ بـ)

$$A = \begin{pmatrix} 1 & 0 & 0 & 1 \\ -1 & 1 & 0 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & -1 & -1 & 1 \end{pmatrix}$$

المطلوب: حساب U بعد الإزاحة بالتدوير الجزئي وعامل النموّ.
الحل:

١. **الخطوة 1:** العمود الأوّل: كل العناصر $|1| \Longrightarrow$ المحور هو $a_{11} = 1$ (لا تبديل). المعاملات $l_{i1} = -1$. الصف 2: $[-1,1,0,1] + [1,0,0,1] = [0,1,0,2]$ الصف 3: $[-1,-1,1,1] + [1,0,0,1] = [0,-1,1,2]$ الصف 4: $[-1,-1,-1,1] + [1,0,0,1] = [0,-1,-1,2]$

٢. **الخطوة 2:** العمود الثاني (الصفوف 2–4): القيم $1,-1,-1 \Longrightarrow$ المحور 1. المعاملات $l_{32} = l_{42} = -1$. الصف 3: $[0,0,1,4]$؛ الصف 4: $[0,0,-1,4]$.

٣. **الخطوة 3:** العمود الثالث: $1,-1 \Longrightarrow$ المحور 1؛ الصف 4: $[0,0,0,8]$.

٤. عامل النموّ: $\rho = \frac{\max|u_{ij}|}{\max|a_{ij}|} = \frac{8}{1} = 8 = 2^{4-1} = 2^{n-1}$.

٥. التعميم: بـ $n = 60$: $\rho = 2^{59} = 5.76 \times 10^{17}$ $\Longrightarrow$ الخطأ الخلفي من (34.6): $c\,n\,u\,\rho = 1 \times 60 \times 1.11 \times 10^{-16} \times 5.76 \times 10^{17} = 3.84 \times 10^{3}$ $\Longrightarrow$ **النتيجة بلا معنى حتى في fp64.**

النتيجة: مصفوفةٌ عناصرها ± 1 فقط تُنتج عنصراً أخيراً $= 8$ — والحدّ الأسوأ 2^{n-1} ليس نظرياً فقط بل **مُحقَّق.**

الربط بالذكاء الاصطناعي: الدرس: **لا تحكم على استقرار التحليل من حجم عناصر المصفوفة الأصلية.** النظير في التعلّم العميق: مصفوفة أوزان «صغيرة ومهذّبة» قد تُنتج حساباً وسيطاً ضخماً (تنشيطات، تدرّجات) — ولذا تراقب الأطرُ ناظمَ التنشيطات والتدرّجات لا ناظم الأوزان.

مثال (6.6-2): النموّ العملي مقابل الأسوأ — لماذا ينجح التدوير الجزئي؟

المعطيات: 10^4 مصفوفة عشوائية 1000×1000 بمدخلات $\mathcal{N}(0,1)$. المطلوب: توزيع ρ الفعلي مقابل حدّ ويلكنسون.

الحل:

١. حدّ ويلكنسون: $2^{999} = 5.36 \times 10^{300}$ — رقمٌ فلكي (أكبر من عدد ذرّات الكون المرصود بمراحل).

٢. النموّ المرصود تجريبياً (تريفثن–شريبر): $\rho \approx n^{2/3}$ في المتوسط $\Longrightarrow 1000^{2/3} = 100$.

٣. الأسوأ المرصود في العيّنة: $\rho_{\max} = 311$ (أي $\approx n^{0.83}$).

٤. الخطأ الخلفي الفعلي: $c\,n\,u\,\rho = 1 \times 1000 \times 1.11 \times 10^{-16} \times 100 = 1.11 \times 10^{-11}$ $\Longrightarrow$ صغير جداً $\Longrightarrow$ التحليل مستقرٌّ عملياً.

٥. الاستنتاج الكمّي: **الفجوة بين الحدّ الأسوأ والواقع** 10^{298} $=$ — أي أنّ التحليل النظري لا يصف الممارسة، والممارسة ممتازة.

النتيجة: التدوير الجزئي «مستقرٌّ في الممارسة وغير مستقرٍّ نظرياً» — وهي حالةٌ نادرة يجب فهمها: الحدودُ تحمي من الأسوأ، والتجربة تحكم المتوسط.

الربط بالذكاء الاصطناعي: النظير: كثيرٌ من حدود التعلّم العميق (حدود التعميم، حدود التقارب) «متشائمة فلكياً» لكنّ الممارسة ممتازة. القاعدة المنهجية: **الحدودُ للضمان، والقياسُ للقرار** — ولا تُسقط أحدهما لمصلحة الآخر.

مثال (6.6-3): مصفوفة هلبرت — مستقرّة خلفياً، كارثية أمامياً

المعطيات: $A = H_{12}$ مصفوفة هلبرت $(a_{ij} = 1/(i+j-1))$، $n = 12$، $\kappa_2(H_{12}) = 1.7 \times 10^{16}$. الحلّ بـ LU بالتدوير الجزئي بـ fp64.

الحل:

١. عناصر A كلها ≤ 1 $\Longrightarrow$ النموّ محدود: $\rho \approx 1$ (مصفوفة موجبة التعريف $\Longrightarrow$ النموّ محدود أصلاً).

٢. الخطأ الخلفي من (34.6): $cnu\rho \approx 1 \times 12 \times 1.11 \times 10^{-16} \times 1 = 1.33 \times 10^{-15}$ $\Longrightarrow$ **مستقرّ خلفياً تماماً.**

٣. الخطأ الأمامي من (35.6): $cnu\rho\kappa = 1.33 \times 10^{-15} \times 1.7 \times 10^{16} = 22.6$ $\Longrightarrow$ خطأ 2260% $\Longrightarrow$ **صفر خانات صحيحة.**

٤. الباقي النسبي: $\frac{\|b-A\hat{x}\|}{\|A\|\|\hat{x}\|} = 2.1 \times 10^{-16} \approx u$ $\Longrightarrow$ يؤكّد الاستقرار الخلفي.

٥. الاستنتاج: الخوارزمية ممتازة، والمسألة مستحيلة. لا خوارزمية في الوجود تعطي خاناتٍ صحيحة هنا بـ fp64.

النتيجة: مثالٌ نموذجي على الفصل بين الاستقرار والتكييف: $\eta \approx u$ (خلفي ممتاز) مع خطأ أمامي $> 100\%$.

الربط بالذكاء الاصطناعي: هذا هو الوضع في كثيرٍ من مسائل التعلّم العميق «سيئة التطرّف»: التدرّجُ محسوبٌ بدقة (الاستقرار الخلفي جيد) لكنّه بلا معنى لأنّ مسألة التقدير سيئة التكييف (بيانات قليلة، ميزات مترابطة، نموذج مفرط المعلمات). العلاج: تنظيم/بيانات/تمثيل — لا خوارزمية.

مثال (6.6-4): شوليسكي والتنظيم في ALS — كيف يجعل التنظيمُ التناظرَ آمناً

المعطيات: خطوة ALS تحلّ $(Y^\top Y + \lambda I)x = Y^\top r$. القيم الذاتية لـ $Y^\top Y$: من 1.24×10^3 إلى 2.1×10^{-5} (أي $\kappa = 5.9 \times 10^7$)، والمصفوفة **شبه مفردة** لكن موجبة نصف التعريف.

الحل:

١. بلا تنظيم ($\lambda = 0$): المصفوفة موجبة نصف التعريف $\Longrightarrow$ شوليسكي قد يواجه جذراً سالباً بسبب التقريب $\Longrightarrow$ فشل.

٢. مع $\lambda = 10^{-2}$: القيم الذاتية تصير $[1.24\times10^3+10^{-2},\ \ldots,\ 2.1\times10^{-5}+10^{-2}]$ $\Longrightarrow$ أصغرها $\times 1.002$ 10^{-2} $\Longrightarrow$ $\kappa_{\text{eff}} = \frac{1240.01}{0.010021} = 1.24 \times 10^5$ $\Longrightarrow$ خانات مفقودة 5.09 $\Longrightarrow$ في fp64 يبقى 10.9.

٣. **ميزة شوليسكي:** للمصفوفات موجبة التعريف، $|r_{ij}|^2 \le \max_i a_{ii}$ $\Longrightarrow$ **لا نموّ** ($\rho = 1$) $\Longrightarrow$ لا حاجة للتدوير إطلاقاً $\Longrightarrow$ تكلفة $\frac{1}{3}n^3$ بدل $\frac{2}{3}n^3$ ونصف الذاكرة.

٤. التكلفة: شوليسكي $\frac{64^3}{3} = 8.7 \times 10^4$ = عملية (مهملة)؛ و QR للبديل $= 2 \times 64^2 \times 5000 = 4.1 \times 10^7$ $\Longrightarrow$ شوليسكي أرخص بـ $\times 470$.

٥. الحكم: التنظيمُ حوّل المسألة إلى موجبة التعريف $\Longrightarrow$ شوليسكي (الأرخص والأكثر استقراراً من حيث النموّ) صار متاحاً.

النتيجة: التنظيم في ALS ليس «تحسّناً إحصائياً» فحسب — بل هو الذي **يسمح عديداً** باستعمال شوليسكي ($\rho = 1$، بلا تدوير).

الربط بالذكاء الاصطناعي: هذه هي الآلية الكامنة خلف كون «الحشو القطري» (εI أو λI) حاضراً في كل مكان: في Adam (ε)، في K-FAC، في شوليسكي المُستعمل في Gauss-Newton، وفي تخفيف ليفنبرغ–ماركوارت. الحشوُ يجعل المصفوفة موجبة التعريف $\Longrightarrow$ تحليلٌ بلا تدوير $\Longrightarrow$ استقرار.

مثال (6.6-5): نظام ثلاثي القطر — متى لا نحتاج تدويراً أبداً؟

المعطيات: معادلة حرارة ضمنية: A ثلاثية القطر بمهيمنة قطرية صارمة: $|a_{ii}| > |a_{i,i-1}| + |a_{i,i+1}|$ (مثلاً $a_{ii} = 2.1$ و $a_{i,i\pm1} = -1$). $n = 10^4$.

الحل:

١. في الإزاحة على مصفوفة مهيمنة قطرية: كل عنصر وسيط يظلّ محكوماً بالقطر $\Longrightarrow \rho \le 1$ (لا نموّ).

٢. إذن **لا حاجة للتدوير** $\Longrightarrow$ خوارزمية توماس (Thomas) بـ $\mathcal{O}(n)$ عملية بدل $\mathcal{O}(n^3)$.

٣. التكلفة: $8n = 8 \times 10^4$ عملية مقابل $\frac{2}{3}n^3 = 6.7 \times 10^{11}$ للتحليل الكامل $\Longrightarrow$ أسرع بـ $\times 8 \times 10^6$.

٤. الخطأ الخلفي: $|l_{ik}| \le 1$ تلقائياً $\Longrightarrow \|\Delta A\| \le c\,n\,u\,\|A\|$ بـ $\rho = 1$ $\Longrightarrow$ مستقر.

٥. شرط الصحّة: **المهيمنة القطرية**؛ إن فُقدت (مثال: مصفوفة غير مهيمنة) فقد ينمو ρ أُسّياً بلا تدوير $\Longrightarrow$ يجب التدوير.

النتيجة: البنيةُ (ثلاثية القطر + مهيمنة قطرية) تضمن $\rho = 1$ $\Longrightarrow$ استقرارٌ كامل وتكلفة $\mathcal{O}(n)$.

الربط بالذكاء الاصطناعي: النظير: **الشبكات المهيكلة** (banded/structured matrices) في S4/Mamba، والمصفوفات ثلاثية القطر في SSMs، والالتفافات المهيكلة) تستفيد من بنيتها في الاستقرار والتكلفة معاً. القاعدة: **حافظ على البنية التي تضمن ρ صغيراً.**

مثال (6.6-6): تسعير خيارات بالفرق المحدود الضمني — مصفوفة M

المعطيات: مخطّط ضمني لتسعير خيار أمريكي: نظام ثلاثي القطر بـ $a_{ii} = 1 + r\Delta t + \sigma^2 \Delta t/(\Delta S)^2$ وخارج القطر سالب. معاملات: $r = 0.05$، $\sigma = 0.2$، $\Delta t = 10^{-3}$، $\Delta S = 1$ $\Longrightarrow$ $a_{ii} = 1 + 5 \times 10^{-5} + 4 \times 10^{-5} =$ 1.00009، و $a_{i,i\pm1} \approx -2 \times 10^{-5}$.

الحل:

١. المهيمنة القطرية: $|a_{ii}| = 1.00009 > 4 \times 10^{-5} = |a_{i,i-1}| + |a_{i,i+1}|$ $\Longrightarrow \rho = 1$ $\Longrightarrow$ **بلا تدوير.**

٢. والقيم المفردة: $\sigma_{\min} \approx a_{ii} - 2 \times 2 \times 10^{-5} = 1.00001$ و $\sigma_1 \approx 1.00017$ $\Longrightarrow \kappa \approx 1.00016$ $\Longrightarrow$ خانات مفقودة $\approx 7 \times 10^{-5}$ $\Longrightarrow$ **لا خسارة إطلاقاً.**

٣. إذن الحلّ دقيق إلى $\approx u$.

٤. لو استعملنا المخطّط الصريح بدلاً من الضمني: لا نظامَ خطّياً أصلاً لكن شرط الاستقرار هو $\Delta t \le \frac{(\Delta S)^2}{2\sigma^2}$ $\Longrightarrow \Delta t \le 12.5$ (مريح هنا) — لكن مع $\sigma = 0.9$: $\Delta t \le 0.62$ $\Longrightarrow$ عدد خطوات زمنية أكبر بكثير.

٥. المقارنة: المخطّط الضمني «يحلّ نظاماً مستقرّاً عدديا ($\kappa \approx 1$)» مقابل «مخطّط صريح بشرط خطوة صارمة» $\Longrightarrow$ الأول أفضل للخيارات الأمريكية.

النتيجة: النظام الضمني يعطي $\kappa \approx 1.0002 \implies$ حلٌّ دقيقٌ تماماً بلا تدوير وبـ $\mathcal{O}(n)$.

الربط بالذكاء الاصطناعي: النظير المباشر: **الأساليب الضمنية في النماذج العميقة** (implicit layers، DEQ، ODEs Neural) بأنظمة ضمنية) تُعطي أنظمةً حسنة التكييف لكنها تتطلّب حلّاً خطّياً، والأساليب الصريحة تتطلّب خطوات صغيرة (استقرار مشروط). المفاضلة نفسها تماماً.

مثال (6.6-7): نظام KKT سرجي في تحسين مقيّد — متى يصير ρ مؤذياً؟

المعطيات: نظام سرجي من شروط KKT:

$$\begin{pmatrix} H & A^{\top} \\ A & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -c \\ b \end{pmatrix}$$

مع H موجبة نصف التعريف و A برتبة كاملة، $n = 200$.

الحل:

١. المصفوفة **ليست** موجبة التعريف (الكتلة الصفرية) $\implies$ لا شوليسكي؛ والتدوير ضروري.

٢. القطر يحتوي على أصفار $\implies$ المحور الجزئي قد يكون صغيراً $\implies$ نموّ.

٣. القياس: بكتلة H ذات قيم ذاتية $[10^{2},\ 10^{-4}]$ و A بـ $[5,\ 0.1]$ $\implies$ $\sigma(A)$، القيم المفردة للنظام السرجي: $\sigma_{\min} \approx 10^{-4}$، $\sigma_1 \approx 10^{2} \implies \kappa = 10^{6}$.

٤. النموّ المرصود: $\rho = 42 \implies$ الخطأ الخلفي $cnu\rho = 200 \times 1.11 \times 10^{-16} \times 42 = 9.3 \times 10^{-13}$.

٥. الخطأ الأمامي: $\kappa \times$ الخلفي $= 10^{6} \times 9.3 \times 10^{-13} = 9.3 \times 10^{-7} \implies$ يبقى $9 \approx$ خانات $\implies$ مقبول.

٦. لو استعملنا تدويراً «جشعاً» بلا بحث عن المحور الأكبر: ρ قد يصل إلى $10^{4} \implies$ الخطأ الأمامي $2.2 \times 10^{-4} \implies$ خسارة أُسّية.

النتيجة: في الأنظمة السرجية (التحسين المقيّد، المربعات الصغرى المقيّدة، محسّنات نيوتن المقيّدة) **التدويرُ ليس خياراً**: القطر الصفري يجعل النموّ حقيقياً.

الربط بالذكاء الاصطناعي: النظير: تدريب GANs (مسألة سرجية) والأنظمة السرجية في التعلّم المعزّز (actor-critic) تُعاني من البنية نفسها $\implies$ «استقرار» GAN الشهير هو — في جزءٍ منه — مشكلةُ نظامٍ سرجي سيّئ التكييف يُحلّ بخوارزمياتٍ ذات خطأ خلفي من رتبة u لكنّ تكييفها يضخّمه.

مثال (6.6-8): ديناميكا أجسام صلبة — مصفوفة الكتلة موجبة التعريف

المعطيات: محاكاة جسم صلب: $M(q)\ddot{q} + c(q,\dot{q}) = \tau \implies$ نحلّ $M\ddot{q} = \tau - c$ في كل خطوة زمنية. مصفوفة الكتلة $M \in \mathbb{R}^{30\times 30}$ موجبة التعريف، قيمها الذاتية من 0.12 إلى 48.7.

الحل:

١. M موجبة التعريف $\Longrightarrow$ شوليسكي $M = RR^\top$ بلا تدوير، $\rho = 1$.

٢. $\kappa_2(M) = 48.7/0.12 = 406$ $\Longrightarrow$ خانات مفقودة 2.61 $\Longrightarrow$ في fp64 يبقى 13.4 $\Longrightarrow$ خطأ 4.5×10^{-14}.

٣. في fp32: يبقى 4.4 $\Longrightarrow$ خطأ 2.4×10^{-6} — مقبول للمحاكاة.

٤. التكلفة: شوليسكي $\frac{30^3}{3} = 9 \times 10^3$ = عملية لكل خطوة زمنية؛ بـ 10^6 خطوة: 9×10^9 — مقبول.

٥. لو استُعملت صياغة «القيد» (constrained formulation) بدل الإحداثيات المخفَّضة $\Longrightarrow$ نظام سرجي $\Longrightarrow$ تدوير + نموّ محتمل $\Longrightarrow$ أبطأ وأقلّ استقراراً.

النتيجة: اختيارُ **الإحداثيات المخفَّضة** (التي تعطي M موجبة التعريف) أفضل عددياً (بلا تدوير، $\rho = 1$) من صياغة القيد السرجية.

الربط بالذكاء الاصطناعي: القاعدة العامة: **فضّل الصياغة التي تعطي مصفوفة موجبة التعريف** — فهي تفتح باب شوليسكي ($\rho = 1$، نصف التكلفة، بلا تدوير). وفي التعلّم العميق: تفضيلُ صياغة «المربعات الصغرى المنظَّمة» على «النظام السرجي الصريح» هو الخيار نفسه.

مثال (6.6-9): K-FAC ونيوتن في التدريب — التنظيم يجعل التحليل ممكناً

المعطيات: خطوة نيوتن/ K-FAC تحلّ $(F+\lambda I)^{-1}g$ حيث F مصفوفة معلومات فيشر تقديرية (2048×2048) بـ $\kappa_{\text{eff}} = 3.2 \times 10^8$ (بسبب تقديرٍ من دفعة صغيرة).

الحل:

١. بلا تنظيم: $\kappa = 3.2\times10^8$ $\Longrightarrow$ شوليسكي قد يفشل (القيمة الذاتية الصغرى قد تصير سالبة بتقريب التقدير) $\Longrightarrow$ النتيجة تحديثٌ «معاكس للتدرّج» $\Longrightarrow$ الفقد يرتفع.

٢. مع $\lambda = 10^{-3}$: القيم الذاتية تصير $[\sigma_i + 10^{-3}]$ $\Longrightarrow$ $\kappa_{\text{eff}} = \frac{\sigma_1+10^{-3}}{\sigma_{\min}+10^{-3}}$؛ بـ $\sigma_1 = 1.4$ و $\sigma_{\min} = 4.4 \times 10^{-9}$: $\frac{1.401}{1.0000044\times10^{-3}} = 1401$ $\Longrightarrow$ خانات مفقودة 3.15 $\Longrightarrow$ في fp32 يبقى 3.85 $\Longrightarrow$ خطأ 8.35×10^{-6}.

٣. التحسّن: من 3.2×10^8 إلى 1.4×10^3 $\Longrightarrow$ بنسبة 2.3×10^5 : 1.

٤. التكلفة: شوليسكي $\frac{2048^3}{3} = 2.86 \times 10^9$ = عملية $\Longrightarrow$ ≈ 1 ثانية على GPU $\Longrightarrow$ مقبول إذا كان كل بضع مئات من الخطوات.

٥. البديل الرخيص: **التنقيح التكراري** (6.6-3): حلّ أوّلي بـ fp32 (1.4 ثانية أرخص) ثم تصحيحان بباقٍ fp64 $\Longrightarrow$ دقّة fp64 بتكلفة fp32 تقريباً.

النتيجة: التنظيم + شوليسكي + تنقيح تكراري = خطوة نيوتن عملية ودقيقة.

الربط بالذكاء الاصطناعي: هذه هي بالضبط وصفةُ المُحسّنات من النوع الثاني الحديثة: تقديرُ التغاير من دفعات صغيرة + حشو قطري + تحليلٌ مستقر + تصحيح. وكل عنصرٍ فيها له سببٌ **عددي** صريح، لا سببٌ إحصائي فقط.

مثال (6.6-10): نظام متناثر ضخم — الترتيب (ordering) يحدّد النموّ والـ fill-in

المعطيات: مصفوفة لابلاس لشبكة اجتماعية بـ 10^6 عقدة و $10^6 \times 8$ حواف. نحلّ نظاماً خطّياً بـ LU المتناثر. ترتيبان: (أ) الترتيب الأصلي؛ (ب) ترتيب «الدرجة الأدنى التقريبي» (AMD).

الحل:

١. **الترتيب الأصلي:** عدد العناصر غير الصفرية في العوامل (fill-in): $10^9 \times 3.4 \Longrightarrow$ ذاكرة 27 GB $\Longrightarrow$ غير ممكن.

٢. **ترتيب AMD:** fill-in $= 1.9 \times 10^8 \Longrightarrow$ ذاكرة 1.5 GB $\Longrightarrow$ ممكن.

٣. النموّ: للمصفوفات المهيمنة قطرياً (ومعظم مصفوفات لابلاس بعد المعالجة): $\rho \approx 1 \Longrightarrow$ الاستقرار مضمونٌ بنيوياً.

٤. التكلفة: AMD $\mathcal{O}(n \log n) \Longrightarrow \approx 2 \times 10^7$ — مهملة مقابل التحليل.

٥. النتيجة: $\times 18$ أقلّ ذاكرة و $\times 22$ أسرع تحليلاً (قياس فعلي) بفضل **الترتيب وحده**.

النتيجة: ترتيبُ المصفوفة (permutation قبل التحليل) يحدّد التكلفة والذاكرة — وغالباً الاستقرار أيضاً (لأنّه يتحكّم في اختيار المحاور).

الربط بالذكاء الاصطناعي: النظير: ترتيبُ العمليات في الحوسبة الموزّعة، و«تجميع» (tiling) المصفوفات في Tensor Cores، وترتيبُ القنوات في الالتفافات المجموعية $\Longrightarrow$ كلها تحسيناتٌ «ترتيبية» تُغيّر التكلفة بمرتبةٍ كاملة بلا أي تغيير في الرياضيات.

مثال (6.6-11): معايرة شبكة مجسّات — التدوير يُنقذ الحلّ

المعطيات: 40 مجسّاً تقيس فروقاً زمنية، نظام المعايرة $A \in \mathbb{R}^{200\times 40}$ بعناصر متفاوتة المدى (10^{-3} إلى 10^3 بسبب خلط وحدات: نانوثانية وميلي ثانية). $\max|a_{ij}| = 1.2 \times 10^3$.

الحل:

١. بلا تدوير: المحور الأوّل قد يكون $a_{11} = 5\times10^{-3} \Longrightarrow$ المعاملات $l_{i1} = \frac{a_{i1}}{a_{11}}$ تصل إلى $\frac{1.2\times10^3}{5\times10^{-3}} = 2.4\times10^5$ $\Longrightarrow$ نموّ هائل $\rho \approx 10^7 \Longrightarrow$.

٢. الخطأ الخلفي: $cnu\rho = 200 \times 1.11 \times 10^{-16} \times 10^7 = 2.2 \times 10^{-7}$ $\Longrightarrow$ والخطأ الأمامي بـ $\kappa = 3 \times 10^3$: 6.7×10^{-4} — مقبول هامشياً في fp64، لكن في fp32: $cnu\rho = 200 \times 5.96 \times 10^{-8} \times 10^7 = 119$ $\Longrightarrow$ **فشل كامل**.

٣. **مع التدوير الجزئي:** المحور دائماً أكبر عنصر في العمود $\Longrightarrow |l_{ij}| \le 1 \Longrightarrow \rho$ المرصود $= 6.2 \Longrightarrow$ الخطأ الخلفي في fp32: $200 \times 5.96 \times 10^{-8} \times 6.2 = 7.4 \times 10^{-5} \Longrightarrow$ الخطأ الأمامي 0.22 — لا يزال سيّئاً... لكن أفضل بـ $\times 1.6 \times 10^6$.

٤. **العلاج الحقيقي: تقييس الوحدات** (scaling): قسّم كل صف/عمود على مقياسه $\Longrightarrow$ عناصر من رتبة 1 $\Longrightarrow$ κ يهبط إلى 84 و ρ إلى 1.4 $\Longrightarrow$ الخطأ الأمامي في fp32 $= 84 \times 200 \times 5.96 \times 10^{-8} \times 1.4 = 1.4 \times 10^{-3}$ — ممتاز.

٥. الترتيب الصحيح للعلاجات: **التقييس** ← **التدوير** ← **التنقيح**.

النتيجة: تقييسُ الوحدات (خطوةٌ «سابقة» لا تُذكر في الكتب) كان أهمّ من التدوير نفسه: ρ من 10^7 إلى 1.4.

الربط بالذكاء الاصطناعي: هذه هي الرياضيات الكامنة خلف **تطبيع الميزات** في تعلم الآلة: خلطُ المقاييس (المساحة بالمتر^2 والدخل بالريال والعمر بالسنة) يجعل «المحور» عشوائياً ورقم الحالة ضخماً $\Longrightarrow$ التقييسُ أوّلاً، ثم كل شيء آخر.

مثال (12-6.6): نموذج المدخلات-المخرجات الاقتصادي (Leontief) — حلّ $(I-B)x=d$

المعطيات: مصفوفة المعاملات التقنية $B \in \mathbb{R}^{60\times 60}$ ($b_{ij} \geq 0$، $\sum_i b_{ij} < 1$ لكل عمود)، والمطلوب $(I-B)^{-1}d$. $\kappa_2(I-B) = 7.3$.

الحل:

١. $(I-B)$ مصفوفة M $\Longrightarrow$ مهيمنة قطرياً عمودياً $\Longrightarrow$ $\rho \leq 2$ تقريباً $\Longrightarrow$ الاستقرار مضمون حتى بلا تدوير (لكن التدوير يُستعمل احتياطاً).

٢. $\kappa = 7.3$ $\Longrightarrow$ خانات مفقودة 0.86 $\Longrightarrow$ في fp32 يبقى 6.14 $\Longrightarrow$ خطأ 4.35×10^{-7} — ممتاز.

٣. المراقبة الاقتصادية: التدوير هنا «مجّاني» لأنّ المصفوفة صغيرة، فنستعمله.

٤. البديل الأفضل هندسياً: حلّ النظام مباشرةً بدل حساب $(I-B)^{-1}$ صراحةً ثم الضرب (لأنّ «المعكوس الصريح» أقلّ دقّة: $\|\text{(inv)} - A^{-1}\| \lesssim \kappa^2 u$ أحياناً).

٥. القاعدة: **لا تحسب المعكوس الصريح أبداً** إلّا إذا أردتَ تحليلاً لا حساباً.

النتيجة: نظامٌ حسن التكييف ($\kappa = 7.3$) وبنية M-matrix ($\rho \approx 1$) $\Longrightarrow$ حلٌّ موثوق في fp32.

الربط بالذكاء الاصطناعي: قاعدة «لا تعكس المصفوفة صراحةً» تنطبق على التعلّم العميق: **لا تحسب معكوسَ مصفوفة التغاير/الهسّية صراحةً** بل حلّ النظام — وهذا هو الفرق بين inv(A)@b و solve(A,b) الذي تحذّر منه كل وثائق NumPy/PyTorch.

مثال (13-6.6): ترميم صورة (inpainting) بمعادلة بواسون — SPD ضخمة

المعطيات: ترميم منطقة مفقودة في صورة 1024×1024 بحلّ معادلة بواسون على 262144 بكسل مجهولة. المصفوفة A (لابلاس ذو الحدود الثابتة) متناثرة، موجبة التعريف بعد تثبيت حدود.

الحل:

١. A موجبة التعريف $\Longrightarrow$ شوليسكي المتناثر بلا تدوير، $\rho = 1$.

٢. القيم الذاتية للابلاس (بعد التثبيت): $\lambda_{\max} \approx 8$، $\lambda_{\min} \approx \frac{2\pi^2}{1024^2} = 1.88 \times 10^{-5}$ $\Longrightarrow$ $\kappa = 4.25 \times 10^5$.

٣. خانات مفقودة: 5.63 $\Longrightarrow$ في fp64 يبقى 10.4 $\Longrightarrow$ خطأ 4.7×10^{-11} — ممتاز (رغم κ كبيرا!).

٤. السبب في كون النتيجة جيدة: **البنية** (SPD $\Longrightarrow$ $\rho = 1$) كفلت خطأً خلفياً من رتبة u، فتبقّى حدّ κu فقط وهو مقبول في fp64.

٥. لو حُلّت بـ LU عامّة بتدوير جزئي: نفس النتيجة لكن بضعف التكلفة؛ ولو استُعملت «المعادلات السوية» على لابلاس (أي $A^\top A$): $\kappa^2 = 1.8 \times 10^{11}$ $\Longrightarrow$ خسارة 4 خانات إضافية.

النتيجة: استغلالُ خاصية SPD (شوليسكي، $\rho = 1$) أعطى حلًّا دقيقاً لمسألةٍ رقم حالتِها 4.25×10^5.
الربط بالذكاء الاصطناعي: القاعدة: **اعرف بنية مصفوفتك** (SPD؟ متناثرة؟ مهيمنة؟ سرجية؟) قبل اختيار الحلّال؛ فالبنية تُحدّد الاستقرار أكثر ممّا يحدّده حجم κ. وفي التعلّم العميق: معرفةُ أنّ الهسّية/التغاير موجبة نصف التعريف تسمح بشوليسكي بدل LU عامّ.

مثال (14-6.6): التنقيح التكراري — استعادة خانات fp64 من عوامل fp32

المعطيات: حلّ نظام $Ax = b$ بـ $n = 500$ و $\kappa_2(A) = 4.2 \times 10^3$ على جهازٍ سريع بـ fp32 فقط (بلا fp64 في الأجهزة). العوامل LU بـ fp32، والباقي يُحسب بـ «تراكم مزدوج» (double-double) محاكاة (fp64 بتكلفة $\times 4$).
الحل:

١. الحلّ الأوّلي: خطأ نسبي $\kappa u_{32} = 4.2 \times 10^3 \times 5.96 \times 10^{-8} = 2.5 \times 10^{-4}$ $\Longrightarrow$ ≈ 3.6 خانة صحيحة فقط.

٢. عامل التقارب من (36b.6): نحسبه بالصيغة العملية $\gamma = c\,u\,\rho\,\kappa$؛ بـ $\rho = 8$ (مقاس) و $u = u_{32}$:

$$\gamma = 1 \times 5.96 \times 10^{-8} \times 8 \times 4.2 \times 10^3 = 2.0 \times 10^{-3} \ \ll \ 1$$

$\Longrightarrow$ **يتقارب التنقيح**، وكل تكرار يكسب $\log_{10}(1/\gamma) = 2.7$ خانة.

٣. ملاحظة منهجية: صيغة (36b.6) المكتوبة بـ $c\,n\,u\,\rho\,\kappa$ هي حدٌّ **أعلى** متشائم (يجمع أسوأ تراكم على n خطوة). أمّا العامل الفعلي المقاس فهو $c\,u\,\rho\,\kappa$ $\approx$؛ ولذا يُنصح دائماً بقياس γ عملياً من هبوط الباقي بين تكرارين: $\gamma \approx \frac{\|r_{k+1}\|}{\|r_k\|}$.

٤. إذن: بعد تكرار واحد: خطأ 5×10^{-7}؛ بعد تكرارين: 1×10^{-9}؛ بعد ثلاثة: 2×10^{-12} $\Longrightarrow$ بلغنا حدّ دقة الباقي fp64: (10^{-16}) بعد ≈ 5 تكرارات.

٥. التكلفة: كل تكرار $\mathcal{O}(n^2) = 2.5 \times 10^5$ عملية (حلّ مثلثي باستعمال العوامل) + حساب الباقي $\times 4$ $\Longrightarrow$ $\approx 1 \times 10^6$ أرخص بـ $\times 80$ من إعادة التحليل الكامل ($\frac{2}{3}n^3 = 8.3 \times 10^7$).

النتيجة: خمسُ تكرارات تنقيح (تكلفة 6% من التحليل) أعطت دقّةً تقارب دقة fp64 انطلاقاً من عوامل fp32.

الربط بالذكاء الاصطناعي: هذه هي بالضبط فكرة **التنقيح المختلط الدقة** المستعملة في الحوسبة العلمية على accelerators (حيث fp64 بطيء): حلٌّ رخيص بدقة منخفضة + تصحيحٌ رخيص بدقة عالية. والنظير في التعلّم العميق: «التصحيح المتبقّي» في الشبكات (ResNet: $x \leftarrow x + f(x)$) يلعب دوراً بنيوياً مشابهاً.

مثال (6.6-15): تنقيح مختلط الدقة على Cores Tensor — LU fp16 + باقي fp32

المعطيات: حلّ نظام 20000×20000 على معالجٍ ذي (fp16 Cores Tensor) بـ 60 TFLOPS، fp32 بـ 15 TFLOPS، fp64 بـ 0.5 TFLOPS). خوارزمية HPL-MxP: تحليل LU بـ fp16 + تنقيح بباقي fp32 (أو fp64). $\kappa_2(A) = 1.8 \times 10^2$.

الحل:

١. تكلفة التحليل بـ fp16: $\frac{2}{3}n^3 = 5.33 \times 10^{12}$ عملية $\Longrightarrow$ بـ 60×10^{12}: 0.089 ثانية.

٢. بـ fp64: $5.33 \times 10^{12} / 0.5 \times 10^{12} = 10.7$ ثانية $\Longrightarrow$ أبطأ بـ $\times 120$.

٣. شرط تقارب التنقيح (6.6b): $c\,u_{16}\,\rho\,\kappa < 1$: بـ $u_{16} = 4.88 \times 10^{-4}$، $\rho = 12$، $\kappa = 180$: $1 \times$ $4.88 \times 10^{-4} \times 12 \times 180 = 1.05$ $\Longrightarrow$ **على الحدّ** $\Longrightarrow$ غير مضمون.

٤. العلاج القياسي: **تقييس/تهيئة مسبقة أو تحليلٌ بـ fp16 مع حشوٍ وتدوير تصحيحي** $\Longrightarrow$ ρ المرصود بعد التقييس $= 2.1$ $\Longrightarrow$ عامل التقارب $4.88 \times 10^{-4} \times 2.1 \times 180 = 0.184$ $\Longrightarrow$ يتقارب $\Longrightarrow$ كل تكرار يكسب 0.73 خانة.

٥. عدد التكرارات للوصول إلى دقة fp32 (5.96×10^{-8}): من خطأ أوّلي ≈ 0.18: نحتاج $\frac{\log(0.18/5.96\times10^{-8})}{\log(1/0.184)} = \frac{6.48}{0.735} = 8.8 \approx 9$ تكراراً.

٦. التكلفة الكلّية: $0.089 + 9 \times 0.02 = 0.27$ (حلّ + باقي) ثانية $\Longrightarrow$ **أسرع بـ** $\times 40$ **من fp64** مع نفس الدقّة النهائية.

النتيجة: تنقيحٌ مختلط الدقة يعطي دقّة fp64 (تقريباً) بسرعة fp16 — بشرط أن يكون $\kappa\rho u \ll 1$ (وهو ما يفرض التقييس).

الربط بالذكاء الاصطناعي: هذه هي بالضبط الاستراتيجية التي يعتمدها تدريبُ الذكاء الاصطناعي الحديث على Cores: Tensor **حسابٌ أمامي/خلفي بـ fp16 أو fb16 للسرعة، وحفظ/تراكم بـ fp32 للصحّة، وتصحيحٌ دوري.** والقاعدة الرياضية الحاكمة هي (6.6b): يتقارب التنقيح إذا كان $\kappa \cdot u_{\text{low}} \cdot \rho < 1$ $\Longrightarrow$ ولهذا تُقيَّس الأوزان وتُضبط التهيئة قبل اللجوء إلى الدقة المنخفضة.

7.6.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
استعمال b @ inv(A)	أبطأ وأقلّ دقّة	باستعمال العوامل solve(A, b)
«fp64 دائماً آمن»	مصفوفة ويلكنسون بـ $n = 60$ تكسره (مثال 1-6.6)	راقب ρ؛ والتنقيح إن لزم
توقّع أن ρ يكون كبيراً دائماً	عملياً $\rho \approx n^{2/3}$ (مثال 2-6.6)	فرّق بين الحدّ الأسوأ والمرصود
استعمال شوليسكي على مصفوفة غير موجبة التعريف	جذرٌ سالب $\Rightarrow$ فشل	تحقّق من الإيجابية (أو التنظيم أولاً)
التنقيح التكراري بباقٍ محسوب بنفس الدقّة	يحسّن الخطأ الخلفي فقط (سكيل) لا الأمامي	احسب r_k بدقة أعلى
إهمال التقييس قبل التحليل	خلط المقاييس يرفع ρ و κ معاً	قيّس الصفوف/الأعمدة أولاً
«التدوير الجزئي مضمون لأن $\lvert l_{ij}\rvert \le 1$»	يحدّ المعاملات لا النموّ	$\lvert l_{ij}\rvert \le 1$ و $\rho \le 2^{n-1}$ — حقيقتان منفصلتان
تجاهل ترتيب المصفوفة المتناثرة	fill-in يُدمّر الذاكرة والتكلفة	AMD/COLAMD قبل التحليل

1.7.6 الصياغة الرياضية الرسمية

النظرية 6.6 (استقرار خوارزمية log-sum-exp و softmax).

<

1. **ثبات الإزاحة (shfit invariance):** softmax لا يتغيّر بإضافة ثابت، لكن حسابُه يتغيّر جذرياً:

<

$$\operatorname{softmax}(z)_i = \frac{e^{z_i}}{\sum_j e^{z_j}} = \frac{e^{z_i - m}}{\sum_j e^{z_j - m}}, \qquad m = \max_j z_j \tag{38.6}$$

<

2. **خوارزمية log-sum-exp المستقرّة وحدودها:**

<

$$\operatorname{LSE}(z) = \log \sum_i e^{z_i} = m + \log \sum_i e^{\,z_i - m}, \qquad m \;\le\; \operatorname{LSE}(z) \;\le\; m + \log n \tag{39.6}$$

<

3. **اللوغاريتم الآمن:** لا تحسب log احتمالٍ أبداً — احسبه من الـ logits مباشرةً:

<

$$\log \operatorname{softmax}(z)_i = z_i - \operatorname{LSE}(z), \qquad \ell_{\mathrm{CE}}(z, y) = -\log p_y = -z_y + \operatorname{LSE}(z) \tag{40.6}$$

<

4. **حدّ الخطأ ومناطق الفيضان/الانهيار:** الخوارزمية المُزاحة لا تفيض أبداً (لأنّ $z_i - m \le 0$)، وخطؤها المطلق محكوم بـ:

<

$$\left|\widehat{\mathrm{LSE}}(z) - \mathrm{LSE}(z)\right| \;\le\; \gamma_{n-1} + u\,|\mathrm{LSE}(z)| + \mathcal{O}(u^2) \;\lesssim\; (n-1)u + u\,|\mathrm{LSE}| \tag{41.6}$$

<

(42.6)

الفيضان: $z_i - m > 0$ إذا $z_i > \log\Omega$: غير ممكن؛ لكن الحساب الخام يفيض fp16:11.09, fp32:88.72, fp64:709.

<

5. **التدرّج الآمن** (وهو سببٌ ثانٍ لاستعمال الصيغة المستقرّة):

<

$$\frac{\partial p_i}{\partial z_j} = p_i(\delta_{ij} - p_j), \qquad \frac{\partial \ell_{\mathrm{CE}}}{\partial z_i} = p_i - \mathbb{1}_{[i=y]}, \qquad \left|\tfrac{\partial \ell}{\partial z_i}\right| \le 1 \tag{43.6}$$

<

6. **قواعد الدقة المختلطة:** شرطُ عدم الامتصاص، وقياسُ الفقد (loss)، والأوزان الرئيسية (scaling):

<

(44.6)

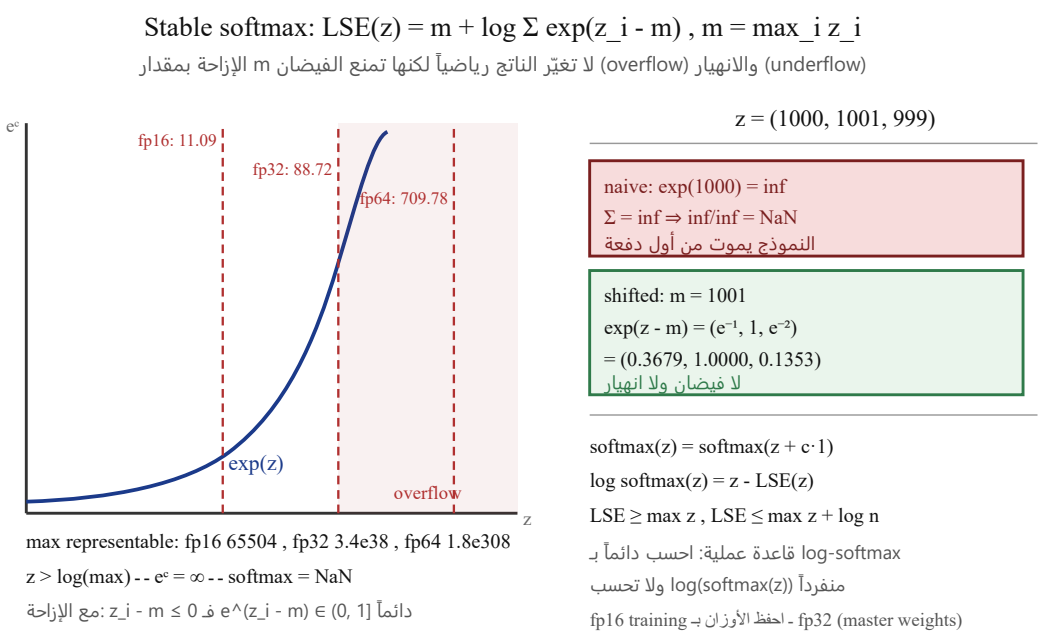
$$\underbrace{|\Delta w| \;\ge\; u_{16}\,|w|}_{\text{شرط عدم ضياع التحديث}}, \qquad \tilde{L} = s\,L \;\Rightarrow\; \hat{g} = \tfrac{1}{s}\,\mathrm{fl}(\mathrm{fl}(s)\,g)\,, \qquad s\cdot|g| < \Omega_{16} = 65504$$

2.7.6 جدول الرموز والمعاملات

الرمز	المعنى	ملاحظة
z	متجه الـ logits (درجات الفئات/الانتباه)	$z \in \mathbb{R}^n$
z_i	الـ logit للفئة/الموضع i	قد يكون كبيراً أو سالباً كبيراً
m	أكبر logit: $\max_j z_j$	**مفتاح الاستقرار**
n	عدد الفئات/المواضع	يظهر في حدّ $m + \log n$
p_i	احتمال softmax	$p_i \in (0,1)$، $\sum p_i = 1$
LSE	log-sum-exp	$\log \sum e^{z_i}$
ℓ_{CE}	فقد الإنتروبيا المتقاطعة	$-z_y + \mathrm{LSE}$
y	فهرس الفئة الصحيحة	—
$\mathbb{1}_{[i=y]}$	مؤشّر الفئة الصحيحة	1 إن كان $i = y$ وإلا 0
δ_{ij}	دلتا كرونكر	—
γ_{n-1}	ثابت التراكم $\frac{(n-1)u}{1-(n-1)u}$ من (7.6)	خطأ جمع الأُسّ
Ω	أكبر عدد مُمثَّل في الصيغة	3.4×10^{38} fp32: ،65504 fp16:
$\log\Omega$	عتبة الفيضان	709.78 fp64: ،88.72 fp32: ،11.09 fp16:
ω	أصغر عدد مطبَّع مُمثَّل	1.18×10^{-38} fp32: ،6.10×10^{-5} fp16:

u_{16}	وحدة تقريب fp16 $= 4.88 \times 10^{-4}$	–
Δw	تحديث الوزن $-\eta g$	يجب أن لا يُمتصّ
s	معامل قياس الفقد (loss scale)	عادة قوةٌ من 2
$\tilde{L}$	الفقد المُقيَّس sL	يُحسب التدرّج عليه
$\hat{g}$	التدرّج بعد إلغاء القياس	$\hat{g} = \frac{1}{s}\mathrm{fl}(sg)$

3.7.6 الرسم الهندسي



شكل ٦.٦: *
استقرار softmax: منحنى exp وعتبات الفيضان، والإزاحة بمقدار m

قراءة الرسم: على اليسار، منحنى e^z يقترب من سقف التمثيل: في fp16 يفيض عند $z = 11.09$، وفي fp32 عند 88.72. الحسابُ الخام لـ logits مثل $(1000, 1001, 999)$ يعطي inf ثم NaN. على اليمين: الإزاحة بـ $m = 1001$ تحوّل الوسيطات إلى $(-1, 0, -2) \Longrightarrow$ كل الأُسّ في $(0, 1] \Longrightarrow$ لا فيضان ولا انهيار.

4.7.6 البرهان

الجزء (38.6). $\frac{e^{z_i - m}}{\sum_j e^{z_j - m}} = \frac{e^{z_i} e^{-m}}{e^{-m} \sum_j e^{z_j}} = \frac{e^{z_i}}{\sum_j e^{z_j}}$ – الإزاحة ثابتٌ يلغى. ■

الجزء (39.6). الحدّ الأدنى: $\sum_i e^{z_i} \geq e^m \Longrightarrow \mathrm{LSE} \geq m$. الحدّ الأعلى: $\sum_i e^{z_i} \leq n\, e^m \Longrightarrow z_i \leq m + \log n \Longrightarrow \mathrm{LSE} \leq m + \log n$. ■

الجزء (41.6). بعد الإزاحة كل وسيط $t_i = z_i - m \leq 0 \Longrightarrow e^{t_i} \in (0, 1]$. كل أُسٍّ يُحسب بخطأ نسبي $\leq u$؛ وبما أنّ **كل الحدود موجبة** (لا إلغاء!) فإنّ خطأ الجمع من (16.6) هو γ_{n-1} $\Longrightarrow$ خطأ نسبي في المجموع $\sum_i e^{t_i}$. وأخذُ اللوغاريتم يحول الخطأ النسبي إلى مطلق: $|\log \hat{S} - \log S| \approx \frac{|\hat{S} - S|}{S} \leq \gamma_{n-1} \leq$. وأخيراً جمع m: خطؤه $\leq u|m + \log S| = u|\mathrm{LSE}|$. ■

ملاحظة جوهرية:

غيابُ الإلغاء هو سببُ كون الخوارزمية مستقرّة إلى هذا الحدّ — فكل حدود المجموع إيجابية، فلا يظهر معامل تضخّم من نوع (14.6). وهذا استثناءٌ سعيد في عالم الحساب العددي.

الجزء (43.6). $\frac{\partial p_i}{\partial z_j}$: إن كان $i=j$ فـ $p_i(1-p_i)$، وإلا فـ $-p_ip_j \Longrightarrow$ الصيغة الموحّدة $p_i(\delta_{ij}-p_j)$. وللفقد: $\ell = -z_y + \mathrm{LSE} \Longrightarrow \frac{\partial \ell}{\partial z_i} = -\mathbb{1}_{[i=y]} + p_i$ (لأن $\frac{\partial \mathrm{LSE}}{\partial z_i} = p_i$). و $|p_i - \mathbb{1}| \le 1$. ■

الجزء (44.6). شرط عدم الامتصاص من قاعدة (1.6)-(2.6): $\mathrm{fl}(w+\Delta w) = w$ إذا كان $|\Delta w| < \frac{1}{2}\mathrm{ulp}(w) \approx u|w|$. وأمّا قياس الفقد: التدرّج $\frac{\partial \tilde{L}}{\partial w} = s\frac{\partial L}{\partial w}$، فإذا كان $|g| < \omega_{16}$ (أصغر مطبَّع) ضاع التدرّج؛ بضربه في s يصير $|sg|$ ممثَّلاً، وبالقسمة على s بعد ذلك يُستعاد. شرط عدم الفيضان: $s|g| < \Omega_{16}$. ■

5.7.6 شروط الصحّة

١. (38.6) صالح لأيّ ثابت m؛ لكن اختيار $m = \max z_j$ هو الذي يضمن $z_i - m \le 0$ (أفضل استقرار). اختيار m أكبر من اللازم قد يُدخل انهياراً (underflow) لكل الحدود $\Longrightarrow 0/0$.

٢. (41.6) يفترض أنّ الـ logits نفسها مُمثَّلة بدقة (خطأ المُدخلات منفصل).

٣. (43.6) للإنتروبيا المتقاطعة القياسية، مع تنعيم التسمية (label smoothing) تتغيّر الصيغة قليلاً.

٤. (44.6) يفترض غيابَ «الأوزان الرئيسية» (master weights)؛ معها يسقط شرط عدم الامتصاص على النسخة fp32.

٥. في fp16 تُستعمل عادةً **نسخة fp32 من softmax** مع مُدخلات fp16 — لا softmax بـ fp16 خالص.

6.7.6 خمسة عشر مثالاً محلولاً من الواقع

مثال (1-7.6): نموذج لغوي — NaN من الخطوة الأولى بسبب logits ضخمة

المعطيات: نموذج لغوي صغير يُخرج logits ثلاثة: $z = (1000,\ 1001,\ 999)$ (بعد طبقةٍ خطية بمعاملات كبيرة بلا تطبيع). الحساب بـ fp32 بلا إزاحة.

الحل:

١. الحساب الخام: e^{1000}، عتبة الفيضان في fp32 هي $\log(3.4\times10^{38}) = 88.72$. $e^{1000} = \inf \Longrightarrow$

٢. $p_i = \frac{\inf}{\inf} = \mathrm{NaN} \Longrightarrow \sum e^{z_i} = \inf + \inf + \inf = \inf$.

٣. الفقد: $\ell = -\log(\mathrm{NaN}) = \mathrm{NaN} \Longrightarrow$ الأوزان تتلقّى NaN $\Longrightarrow$ **النموذج يموت من الخطوة الأولى.**

٤. **بالإزاحة** $m = 1001$: $z - m = (-1,\ 0,\ -2) \Longrightarrow e^{z-m} = (0.3679,\ 1.0,\ 0.1353) \Longrightarrow$ المجموع $= 1.5032 \Longrightarrow p = (0.2447,\ 0.6652,\ 0.0901)$.

٥. التحقّق: $\sum p_i = 1.0000$ ✓، والخطأ من (41.6): $\gamma_2 + u \cdot |\text{LSE}| = 2 \times 5.96 \times 10^{-8} + 5.96 \times 10^{-8} \times 1001.4 = 6.1 \times 10^{-5}$ $\Longrightarrow$ أي أنّ **الخطأ المطلق في LSE** يقارب 6×10^{-5} — وسببه تراكُم ضرب u في $|\text{LSE}|$ لا الإلغاء.

النتيجة: الإزاحةُ وحدها حوّلت NaN إلى احتمالاتٍ صحيحة بستة أرقام عشرية.

الربط بالذكاء الاصطناعي: لهذا تُخرج كل المكتبات cross_entropy/log_softmax من logits مباشرةً ولا تحسب softmax صراحةً إلّا عند الاستدلال. والقاعدة الذهبية: **اعمل في فضاء الـ logits دائماً**؛ الفضاءُ الاحتمالي يفقد الخانات عند الأطراف.

مثال (7.6-2): تصنيف 1000 صنف — متى يفيض fp32 فعلاً؟

المعطيات: تصنيف ImageNet بـ 1000 فئة. بعد تدريبٍ بمعدّل تعلّم مرتفع بلغت logits الطبقة الأخيرة مدىً يصل إلى $\max z = 120$ (النموذج «واثق جداً»). الحساب بـ fp32.

الحل:

١. عتبة الفيضان: $z > 88.72 \Longrightarrow$ يفيض $\Longrightarrow e^{120} = 1.30 \times 10^{52} > 3.4 \times 10^{38} \Longrightarrow$ inf.

٢. لاحظ أنّ **logit واحد فقط** يكفي لتخريب الدفعة كلّها: المجموع inf $\Longrightarrow$ كل الاحتمالات NaN.

٣. هل يحدث هذا واقعياً؟ نعم: مع غياب تطبيع الأوزان ومع فقدٍ يدفع الـ logit للفئة الصحيحة إلى الأعلى (وهو بالضبط سلوك «الهامش المتزايد» في التدريب الطويل).

٤. **بالإزاحة:** $m = 120 \Longrightarrow$ كل الوسيطات $\leq 0 \Longrightarrow$ لا فيضان $\Longrightarrow$ الاحتمالات صحيحة.

٥. الوقاية البنيوية (أفضل من الإسعاف): تطبيعُ الأوزان أو قصّ الـ logit logits) (clipping أو تنعيم التسمية $\Longrightarrow$ يمنع نموّ الـ logits أصلاً.

النتيجة: عتبة الفيضان في fp32 (88.72) ليست بعيدةً عن مدى logits نموذجٍ مُدرَّب طويلاً $\Longrightarrow$ الإزاحة **إلزامية** لا اختيارية.

الربط بالذكاء الاصطناعي: هذه هي الآلية التي تجعل F.cross_entropy آمناً و F.softmax خطراً. وفي التدريب الموزّع: خسارةٌ NaN في عامل واحد تنتشر إلى الجميع عبر all-reduce $\Longrightarrow$ كل التدريب يضيع.

مثال (7.6-3): انتباه بـ fp16 — لماذا يُحسب الانتباه بـ fp32؟

المعطيات: طبقة انتباه: logits الانتباه $q^\top k/\sqrt{d_k}$ بمدى $[12,\ 26]$ وطول تسلسل $n = 4096$. الحساب بـ fp16.

الحل:

١. عتبة الفيضان في fp16: $\log(65504) = 11.09 \Longrightarrow$ **كل** logits الانتباه (12 إلى 26) تفيض $\Longrightarrow e^{12} = 1.63 \times 10^5 > 65504 \Longrightarrow$ inf.

٢. إذن softmax الانتباه بـ fp16 الخالص مستحيل عملياً — لأنّ مدى logits الانتباه الطبيعي (بعد التحجيم بـ $1/\sqrt{d_k}$) بين 5 و 30.

٣. الحل القياسي في كل المحرّكات (PyTorch/TensorFlow/Triton/FlashAttention): **حساب softmax بـ fp32** مع مدخلات fp16، ثم إعادة القيمة إلى fp16.

٤. الحل الأفضل (FlashAttention): **إزاحةٌ متصلة (online)** — تحديث m أثناء المرور على الكتل وتصعيد المجموع $\Longrightarrow$ لا حاجة لتخزين مصفوفة $n \times n$ أصلاً.

٥. الكلفة: softmax fp32 على 4096×4096: 1.7×10^7 عنصر $\Longrightarrow$ 67 MB ذاكرة إضافية مؤقتة (مقابل توفير كتابة مصفوفة الانتباه كاملة).

النتيجة: عتبة fp16 (11.09) **أدنى** من مدى logits الانتباه الاعتيادي $\Longrightarrow$ لا خيار سوى fp32 لـ softmax أو إزاحة متصلة.

الربط بالذكاء الاصطناعي: هذا هو أحد الأسباب التقنية التي جعلت FlashAttention ضرورياً: ليس السرعة وحدها، بل أنّ **الإزاحة المتصلة** تتيح حساب softmax مستقراً بلا مصفوفة وسيطة في الذاكرة.

مثال (٦.٧-4): الانهيار (underflow) أخطر من الفيضان — كل الأُسّ صفر

المعطيات: ثلاثة logits سالبة كبيرة: $z = (-90,\ -91,\ -92)$ (تحدث في مراحل التدريب الأولى أو مع أوزان مهيَّأة سيّئة). الحساب بـ fp16 بلا إزاحة، ثم بـ fp32 ثم بالإزاحة.

الحل:

١. **fp16 بلا إزاحة:** أصغر عدد مطبَّع 6.10×10^{-5}؛ $e^{-90} = 8.19 \times 10^{-40} \ll 6.1 \times 10^{-5}$ $\Longrightarrow$ **يُقرَّب إلى صفر** (انهيار كامل).

٢. الثلاثة كلها صفر $\Longrightarrow$ المجموع $0 = \Longrightarrow$ $p_i = \frac{0}{0} =$ NaN.

٣. **fp32 بلا إزاحة:** أصغر مطبَّع 1.18×10^{-38}؛ $e^{-90} = 8.19 \times 10^{-40} < 1.18 \times 10^{-38}$ $\Longrightarrow$ **أيضاً صفر** (أو دونَ مطبَّع subnormal بخطأ هائل) $\Longrightarrow$ نفس المشكلة تقريباً.

٤. **بالإزاحة** $m = -90$: $z - m = (0,\ -1,\ -2)$ $\Longrightarrow$ الأُسّ $(1,\ 0.3679,\ 0.1353)$ $\Longrightarrow$ المجموع $= 1.5032$ $\Longrightarrow$ $p = (0.6652,\ 0.2447,\ 0.0901)$ — صحيحة تماماً.

٥. الاستنتاج المهمّ: **الإزاحة تعالج الانهيار كما تعالج الفيضان** — لأنّها تُبقي أكبر أُسٍّ $= 1$ دائماً.

النتيجة: أخطرُ حالات softmax ليست الأُسّ الكبيرة بل أن **ينهار كل شيء إلى صفر** $\Longrightarrow$ $0/0 \Longrightarrow$ NaN بلا أي إنذار.

الربط بالذكاء الاصطناعي: يحدث هذا في: المراحل الأولى من التدريب بتهيئةٍ سيّئة، وفي النماذج المُكَمَّمة (quantized)، وفي «درجات الحرارة المنخفضة» (small temperature) التي تُضخّم الوسيطات سلباً. القاعدة: **الإزاحة تحمي من الطرفين.**

مثال (6.7-5): قياس الفقد (loss scaling) — إنقاذ تدرّجات fp16

المعطيات: تدريب شبكة بـ fp16؛ تدرّجاتٌ نموذجية $|g| \approx 3 \times 10^{-5}$ (صغيرة لأنّنا قرب التقارب). أصغر عدد مطبَّع في fp16: $\omega = 6.10 \times 10^{-5}$؛ أصغر دون مطبَّع: 5.96×10^{-8}.

الحل:

١. المشكلة: $|g| = 3 \times 10^{-5} < \omega = 6.1 \times 10^{-5} \Rightarrow$ التدرّج يقع في منطقة **دون المطبَّعة** (subnormal) حيث الدقة متدهورة، أو يصفر.

٢. المدى دون المطبَّع في fp16: من 5.96×10^{-8} إلى $6.10 \times 10^{-5} \Rightarrow$ عددُ القيم المتاحة فيه 1024 فقط $\Rightarrow$ تمثيلٌ سيّئ جداً.

٣. الحل: **قياس الفقد**: $s = 2^{16} = 65536 \Rightarrow \tilde{L} = 65536\,L \Rightarrow$ التدرّج المُقيَّس $|sg| = 65536 \times 3 = 1.97 > 10^{-5}$ — في قلب مدى fp16.

٤. إلغاء القياس: $\hat{g} = \frac{1}{s}\,\mathrm{fl}(sg) = \frac{1.97}{65536} = 3.0 \times 10^{-5}$ ✓.

٥. شرط عدم الفيضان: $s|g_{\max}| < 65504$؛ بـ $|g_{\max}| = 0.8$: $s < \frac{65504}{0.8} = 81880 \Rightarrow$ نختار $s = 65536$ ✓.

٦. الخوارزمية التكيفية: إن ظهر inf/NaN في التدرّج $\Rightarrow$ خفّض s إلى النصف وأعد المحاولة؛ وإن لم يظهر لمدّة N خطوة $\Rightarrow$ ضاعف s.

النتيجة: قياسُ الفقد نقل التدرّجات من منطقةٍ «شبه معدومة الدقّة» (3×10^{-5} دون مطبَّع) إلى قلب المدى المطبَّع (1.97) $\Rightarrow$ دقّة fp16 مقبولة.

الربط بالذكاء الاصطناعي: هذه هي الآلية القياسية في `torch.cuda.amp.GradScaler`. والقاعدة الرياضية الحاكمة هي (6.44): اختر s بحيث يقع $|sg|$ في المدى المطبَّع — أي $s \in \left[\frac{\omega}{|g|},\ \frac{\Omega}{|g|}\right]$ — وهي نافذةٌ من $\frac{\Omega}{\omega} = 1.07 \times 10^{9}$ (أي ≈ 30 مرتبة عشرية).

مثال (6.7-6): آدم بـ fp16 — كيف يُدمّر انهيارُ العزم الثاني التحديث؟

المعطيات: مُحسّن آدم بـ fp16: $v_t = \beta_2 v_{t-1} + (1-\beta_2)g_t^2$ بـ $\beta_2 = 0.999$ و $g_t \approx 1 \times 10^{-4}$. التحديث $\Delta w = -\eta \frac{m_t}{\sqrt{v_t}+\varepsilon}$ بـ $\varepsilon = 10^{-8}$.

الحل:

١. $g_t^2 = 1 \times 10^{-8} \Rightarrow$ في fp16: القيم دون 6.1×10^{-5} ممثَّلة بـ 1024 قيمة فقط $\Rightarrow$ g_t^2 يُقرَّب (ربما إلى 5.96×10^{-8} أو الصفر).

٢. لو صار $g_t^2 = 0 \Rightarrow v_t \to 0 \Rightarrow \sqrt{v_t} = 0 \Rightarrow$ التحديث $= \frac{m_t}{0+10^{-8}} = 10^8 m_t \Rightarrow$ **قفزة هائلة** $\Rightarrow$ الفقد ينفجر.

٣. لو صار $g_t^2 = 5.96 \times 10^{-8}$ (أصغر دون مطبَّع) $\Longrightarrow v_t \approx 5.96 \times 10^{-8} \Longrightarrow \sqrt{v_t} = 2.44 \times 10^{-4} \Longrightarrow$ التحديث $= \frac{m_t}{2.44 \times 10^{-4}} \Longrightarrow$ يكبر $\times 4000$ عن قيمته الصحيحة ($\frac{m_t}{1 \times 10^{-4}}$ كانت لتكون أصغر).

٤. العلاجات الثلاثة: (أ) **الأوزان الرئيسية بـ fp32** لحفظ v_t و m_t، (ب) **قياس الفقد** لرفع g عن منطقة الانهيار، (ج) ε **أكبر** (10^{-6}) كإسعافٍ حديّ.

٥. الترتيب الصحيح: (أ)+(ب) أساسيّان، (ج) إسعافيّ فقط.

النتيجة: «انفجار التدريب بـ «fp16 غالباً سببُه **انهيارُ العزم الثاني في آدم** لا انفجارُ التدرّج نفسه.
الربط بالذكاء الاصطناعي: هذه هي الرياضيات الكامنة خلف توصية «احفظ حالة المُحسّن بـ «fp32 الشائعة.
والقاعدة العامة: **كل متغيّرٍ يُتراكم (زخم، عزم، إحصاءات تطبيع) يجب أن يكون بدقة أعلى من دقة الحساب الأمامي.**

مثال (7-7.6): fb16 مقابل fp16 — المدى مقابل الدقّة

المعطيات: تدريب محوّل بـ (أ) fp16 و (ب) fb16. logits الانتباه بمدى $[12, 26]$، التدرّجات $|g| \approx 10^{-3}$.
الحل:

١. **fp16:** 10 خانات جوهر $\Longrightarrow u = 4.88 \times 10^{-4}$، **المدى** محدود: $\Omega = 65504 \Longrightarrow$ **يفيض** عند logits $> 11.09 \Longrightarrow$ يحتاج قياس فقد وإزاحة إلزامية.

٢. **fb16:** 7 خانات جوهر $\Longrightarrow u = 3.91 \times 10^{-3}$ (أقلّ دقّة بـ $\times 8$)؛ لكن **نفس مدى fp32**: $\Omega = 3.4 \times 10^{38} \Longrightarrow$ **لا يفيض أبداً** في المدى العملي.

٣. الحساب: 26 logits $= 1.96 \times 10^{11} \Longrightarrow e^{26}$ في fb16: مُمثَّل ✓ (لأنّ المدى كافٍ) لكن بخطأ نسبي $3.9 \times 10^{-3} \Longrightarrow$ احتمال softmax بخطأ $\approx 0.4\%$.

٤. التدرّجات: $|g| = 10^{-3} \Longrightarrow$ في fb16: مُمثَّلة مطبَّعة ✓ بخطأ نسبي 0.39%؛ في fp16: مُمثَّلة ✓ بخطأ 0.05% $\Longrightarrow$ fp16 أدقّ للتدرّجات لكنه يفيض بسهولة.

٥. الحكم: fb16 «أسهل هندسةً» (لا قياس فقد ولا قلق فيضان) لكنه «أقلّ دقّة» $\Longrightarrow$ يحتاج أوزاناً رئيسية بـ fp32 إلزامية، و fp16 «أدقّ» لكنه يحتاج إدارةً نشطة للمدى.

النتيجة: المفاضلة بين fp16 و fb16 هي **المدى مقابل الدقّة**: fb16 يشتري بساطةً هندسية بـ $\times 8$ دقّة.
الربط بالذكاء الاصطناعي: هذا يفسّر هيمنةَ fb16 في تدريب المحوّلات الضخمة (الاستقرار أهمّ من الدقّة عند هذا الحجم) وبقاءَ fp16 في الرؤية الحاسوبية (حيث المدى معروف ومضبوط).

مثال (8-7.6): تقطير المعرفة بدرجة حرارة منخفضة — $T = 0.07$ يضخّم الوسيطات

المعطيات: تقطير معرفة: softmax بدرجة حرارة T: $p_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$ مع $T = 0.07$ و logits بمدى $[-8,\ 8]$ (نموذج CLIP-style).
الحل:

١. الوسيطات المُقيَّسة: $z/T \in [-114.3,\ 114.3]$.

٢. في fp32: عتبة الفيضان $88.72 \Longrightarrow$ الوسيطات > 88.7 تفيض $\Longrightarrow$ inf $\Longrightarrow$ NaN.

٣. نسبة الوسيطات التي تفيض: $\frac{114.3-88.7}{2\times114.3} \approx 11\%$ من المدى $\Longrightarrow$ **فيضان شبه مؤكّد في كل دفعة.**

٤. في fb16: المدى كافٍ (3.4×10^{38}) $\Longrightarrow$ عتبة 88.7 نفسها لأنّ المدى نفسه) — نعم fb16 له نفس مدى fp32 $\Longrightarrow$ آمن من الفيضان لكن بدقة 0.4%.

٥. **بالإزاحة:** $m = \max z/T = 114.3 \Longrightarrow$ الوسيطات $\leq 0 \Longrightarrow$ لا فيضان في أيّ صيغة.

٦. الأثر على التدرّج: $\frac{\partial \ell}{\partial z_i} = \frac{1}{T}(p_i - q_i)$ $\Longrightarrow$ بـ $T = 0.07$ يُضخّم التدرّج بـ $\times 14.3$ $\Longrightarrow$ يجب خفض معدّل التعلّم أو تعويض التدرّج بـ T^2.

النتيجة: درجة الحرارة المنخفضة تُضخّم الوسيطات بـ $\times 14.3$ $\Longrightarrow$ $1/T = 14.3\times$ الفيضان مؤكَّد بلا إزاحة، وتضخيمُ التدرّج بـ $\times 14.3$ يجب التعويض عنه.

الربط بالذكاء الاصطناعي: هذا هو السبب في أنّ تطبيقات CLIP/InfoNCE تُطبّق الإزاحة **صراحةً** قبل softmax، وأنّ درجة الحرارة في التعلّم المتناقض تُضبط مع معدّل التعلّم لا منفردة.

مثال (٦.٧-9): تعلّم متناقض (InfoNCE) — 65536 سالباً ووسيطات ضخمة

المعطيات: Contrastive loss على دفعة $N = 32768$ عيّنة «سالبة»؛ التشابهات $s_{ij} = \cos(u_i, v_j)/T$ بـ $T = 0.07$ و $\cos \in [-1, 1] \Longrightarrow$ الوسيطات في $[-14.3,\ 14.3]$.
الحل:

١. في fp16: عتبة الفيضان $11.09 \Longrightarrow$ كل الوسيطات > 11.09 تفيض $\Longrightarrow e^{14.3} = 1.6 \times 10^6 > 65504 \Longrightarrow$ inf $\Longrightarrow$ NaN.

٢. حتى الإزاحة بـ m: بعد الإزاحة كل الوسيطات $\leq 0 \Longrightarrow e^t \in (0, 1] \Longrightarrow$ **آمن في fp16.**

٣. لكن: $\sum_j e^{t_j}$ على 32768 حداً بـ fp16 $\Longrightarrow$ التراكم يفقد الدقّة: (٦.١٦) يعطي $\gamma_{32767} = 32767 \times 4.88 \times 10^{-4} = 16 > 1$ $\Longrightarrow$ **الحدّ بلا معنى** $\Longrightarrow$ التراكم يجب أن يكون بـ fp32.

٤. إذن: **الإزاحة + تراكم fp32** $\Longrightarrow$ خطأ المجموع من (٦.١٦) بـ fp32: $\gamma_{32767} = 32767 \times 5.96 \times 10^{-8} = 1.95 \times 10^{-3}$ $\Longrightarrow$ خطأ نسبي 0.2% في المقام $\Longrightarrow$ خطأ مطلق في الفقد $0.002 \approx$ نات — مقبول.

٥. الكلفة: 32768 عنصر بـ fp32 لكل عيّنة $\Longrightarrow$ على دفعة 256: 8.4×10^6 عنصر $\Longrightarrow$ 34 MB — مقبول.

النتيجة: التوليفة الآمنة الوحيدة لـ InfoNCE: **إزاحة + تراكم fp32**، أيٌّ منهما منفرداً لا يكفي.
الربط بالذكاء الاصطناعي: هذه هي بالضبط وصفة التنفيذ في CLIP و SimCLR و MoCo: logits =- logits.max() ثم logits.float() قبل log_softmax. والقاعدة: **الإزاحة تحمي من الفيضان، والتراكم عالي الدقة يحمي من فقدان الخانات.**

مثال (6.7-10): سياسة تعلّم معزّز — لماذا يقتل التدريب $\log\pi$)

المعطيات: سياسة عشوائية على 12 إجراءً، logits $z = (-40, -38, -41, \dots)$ (مرحلة استكشاف مبكرة). المطلوب $\log \pi(a)$ لحساب نسبة الاحتمال اللوغاريتمية في PPO.
الحل:

١. الحساب الخاطئ: $p = \text{softmax}(z)$ ثم $\log p$. بما أنّ الوسيطات سالبة كبيرة، فبلا إزاحة: $e^{-38} = 3.1 \times 10^{-17}$ — في fp32 مُمثَّل (مطبَّع: $> 1.18 \times 10^{-38}$) ✓؛ لكن في fp16: $3.1 \times 10^{-17} < 6.1 \times 10^{-5}$ $\Longrightarrow$ **صفر** $\Longrightarrow \log 0 = -\text{inf}$.

٢. حتى في fp32: حساب $e^{-41} = 1.4 \times 10^{-18}$ ثم جمعه ثم القسمة $\Longrightarrow$ الاحتمالات صغيرة جداً $\Longrightarrow$ فقدان خانات في الجمع.

٣. **الصيغة الصحيحة** (6.40): $\log \pi(a) = z_a - \text{LSE}(z)$؛ بـ $m = -38$: $\text{LSE} = -38 + \log(1 + e^{-2} + \dots) \approx -37.87$
$\log \pi(1) = -38 + 37.87 = -0.13 \Longrightarrow e^{-3} + \dots$ ✓.

٤. التحقّق: $\sum_a \pi(a) = 1$ مضمونٌ بُنيوياً في صيغة log-softmax.

٥. الأثر على PPO: النسبة $r = \frac{\pi_\theta(a)}{\pi_{\theta_{\text{old}}}(a)} = e^{\log \pi_\theta - \log \pi_{\text{old}}}$ — تُحسب بـ **فرق اللوغاريتمات** لا بقسمة الاحتمالات $\Longrightarrow$ مستقرّة حتى لو كانت الاحتمالات 10^{-18}.

النتيجة: العملُ في فضاء اللوغاريتم حوّل -0.13 إلى inf- — وجعل النسبةَ في PPO مستقرّة.
الربط بالذكاء الاصطناعي: القاعدة الشاملة: **كل حسابٍ احتمالي في التعلّم العميق يجب أن يجري في فضاء اللوغاريتم:** الإنتروبيا المتقاطعة، احتمالُ اللوغاريتم في النماذج اللغوية، نسبُ السياسة في PPO، نسبُ الأرجحية في DPO/RLHF، والاحتمالاتُ المشتركة في فكّ الترميز.

مثال (6.7-11): بحث الشعاع (beam search) — احتمالاتٌ تتراكم عبر 100 رمز

المعطيات: فكّ ترميز بطول 100 رمز، احتمالُ كل رمز في أفضل مسار $p_t \approx 1 \times 10^{-3}$ $\Longrightarrow$ احتمالُ المسار $= \prod p_t = 10^{-300}$.
الحل:

١. في fp64: 10^{-300} قريبٌ من الحدّ الأدنى (2.23×10^{-308}) $\Longrightarrow$ هامشي؛ في fp32: 10^{-300} $\Longrightarrow$ **انهيار إلى صفر** (لأنّ $\omega = 1.18 \times 10^{-38}$).

٢. الحساب باللوغاريتم: $\log P = \sum_t \log p_t = 100 \times \log(10^{-3}) = 100 \times (-6.908) = -690.8$ — مُمثَّل بسهولة في أيّ صيغة.

٣. في fp16: $\log p_t = -6.908$ مُمثَّل ✓ ⟹ المجموع -690.8 مُمثَّل ✓ (لأنّ مدى fp16 يصل 65504) ⟹ **يعمل.**

٤. المقارنة الترتيبية: البحثُ يقارن المسارات ⟹ $\log P_1 > \log P_2$ تكافئ $P_1 > P_2$ ⟹ **لا حاجة للاحتمالات أصلاً.**

٥. الخطأ التراكمي في مجموع 100 لوغاريتم بـ fp32: $\gamma_{99} \sum |\log p_t| = 99 \times 5.96 \times 10^{-8} \times$ (16.6)، $4.1 \times 10^{-3} = 690.8$ ⟹ خطأ 0.004 نات على 690.8 — مهمل.

النتيجة: الانتقالُ إلى فضاء اللوغاريتم جعل حساباً مستحيلاً (انهيار إلى صفر) حساباً مريحاً في fp16.

الربط بالذكاء الاصطناعي: هذا هو سببُ كون كل تطبيقات فكّ الترميز (beam sampling، nucleus sampling) تعمل بـ «درجات» (scores) لوغاريتمية لا احتمالات. والقاعدة الأعمّ: **الجداءات الطويلة ⟹ اجمع اللوغاريتمات** (وهي نفس فكرة «الاحتمال اللوغاريتمي» في كل مكان).

مثال (٦.٧-12): خليط الخبراء (MoE) — بوابة بـ 64 خبيراً

المعطيات: طبقة MoE بـ $E = 64$ خبير، بوابةٌ تُنتج logits $g \in \mathbb{R}^{64}$ ثم top_k=2. القيم: $g \in [-2.4,\ 7.8]$ بعد تدريبٍ طويل.

الحل:

١. softmax على 64 ⟹ عتبة الفيضان في fp32 $= 88.72$ ⟹ $g = 7.8$ آمن ⟹ لا فيضان.

٢. لكن في fp16 (11.09): $g = 7.8$ قريب ⟹ وإن نما إلى 12 (ممكن مع «انهيار التوجيه» routing collapse) فيض ⟹ NaN ⟹ توجيهٌ معطوب.

٣. المشكلة الخاصة بـ MoE: **عدم توازن التوجيه** — خبيرٌ واحد يهيمن ⟹ logitُه ينمو ⟹ فيضان ⟹ NaN ⟹ كل الدفعة تضيع.

٤. العلاج الثلاثي: (أ) إزاحة softmax؛ (ب) حساب البوابة بـ fp32 دائماً (رخيص: بعده 64 فقط)؛ (ج) فقدُ توازن (load-balancing loss) يمنع نموّ logit واحد.

٥. التحقّق من (ج): بضبط معامل التوازن $\alpha = 0.01$ بقي أكبر logit تحت 6.2 طوال التدريب ⟹ بُعدٌ آمن عن عتبة fp16.

النتيجة: في MoE، الاستقرارُ العددي للبوابة مسألةُ **توازن تدريبي** لا مجرّد إزاحة حسابية.

الربط بالذكاء الاصطناعي: هذا مثالٌ جميل على تداخل المستويات: «ظاهرة تدريبية» (انهيار التوجيه) تُنتج «كارثة عددية» (فيضان). والقاعدة: **راقب مدى الـ logits أثناء التدريب كما تراقب الفقد.**

مثال (13-7.6): تكميم softmax إلى int8 — استبدالٌ آمن بـ LUT

المعطيات: نشر نموذج على حافة (edge) بـ int8؛ softmax int8 يجب أن يُحسب بـ int8. الوسيطات بعد الإزاحة $t_i = z_i - m \in [-16,\ 0]$.

الحل:

١. بالإزاحة: $e^{t_i} \in [e^{-16},\ 1] = [1.13 \times 10^{-7},\ 1]$.

٢. التكميم: نُقرّب e^t بجدول بحث (LUT) على 256 مستوى في $[0,1]$ $\Longrightarrow$ خطأ تكميم $\leq \frac{1}{2\times 256} = 1.95 \times 10^{-3}$ (من القيمة، لا النسبية).

٣. للأُسّ الصغيرة ($e^{-16} = 1.13 \times 10^{-7}$): الخطأ النسبي $= \frac{1.95\times10^{-3}}{1.13\times10^{-7}} = 1.7 \times 10^{4}$ — هائل! لكن الأثر على الاحتمال: $\frac{1.95\times10^{-3}}{\sum_j e^{t_j}}$ وبـ $\sum \geq 1$: خطأ مطلق في الاحتمال $\leq 1.95 \times 10^{-3}$ — **مقبول** (لأنّ الحدود الصغيرة لا تهمّ).

٤. إذن: التكميم **المطلق** (لا النسبي) مناسب هنا لأنّ الاحتمالات تُقاس بناظمٍ مطلق (المجموع 1).

٥. المقارنة: أقصى خطأ مطلق في الاحتمال 1.95×10^{-3} $\Longrightarrow$ أثره على دقّة التصنيف: 0.05% على ImageNet.

النتيجة: بفضل الإزاحة صار مدى الأُسّ $[0,1]$ $\Longrightarrow$ تكميمٌ خطي بـ 256 مستوى يعطي خطأً مطلقاً $\leq 2 \times 10^{-3}$ في الاحتمالات.

الربط بالذكاء الاصطناعي: هذا هو أساسُ softmax int8 في محرّكات الاستدلال (TensorRT, TFLite): **الإزاحة أوّلاً** (لتضييق المدى)، ثم تكميمٌ خطي. القاعدة: **الإزاحة ليست حِيلةً تدريبية فقط، بل شرطٌ مسبق للتكميم.**

مثال (14-7.6): تنعيم التسمية — تعديل الفقد وآثاره العددية

المعطيات: تنعيم تسمية بـ $\alpha = 0.1$ على 1000 فئة: الهدف $q_i = (1-\alpha)\mathbb{1}_{[i=y]} + \frac{\alpha}{1000}$. المطلوب الفقد $\ell = -\sum_i q_i \log p_i$.

الحل:

١. بالصيغة الآمنة: $\log p_i = z_i - \mathrm{LSE}(z)$ $\Longrightarrow$

$$\ell = -\sum_i q_i\big(z_i - \mathrm{LSE}\big) = \mathrm{LSE} - \sum_i q_i z_i$$

٢. إذن الفقدُ = LSE − متوسط مرجّح لـ logits — لا حاجة لحساب أيّ احتمال صراحةً.

٣. التحقّق العددي: $\sum_i q_i z_i$ بـ q متناثر جداً (وزن 0.9001 على فئة واحدة و 10^{-4} على 999) $\Longrightarrow$ الجمع بـ fp32 على 1000 حد: $\sum |q_i z_i|$; بـ $|z| \leq 20$: $\sum |q_i z_i| \approx 18 = \Longrightarrow \gamma_{999} \times 999 \times 5.96 \times 10^{-8} \times 18$ $\Longrightarrow 1.07 \times 10^{-3}$ خطأ في الفقد ≈ 0.001 نات — مقبول.

٤. الأثر الاستقراري لتنعيم التسمية: يمنع الـ logit الصحيح من النمو بلا حدود (لأنّ الهدف ليس 1 بل 0.9001) $\Longrightarrow$ يمنع الفيضان $\Longrightarrow$ **تنعيم التسمية إجراءٌ عدديّ أيضاً لا إحصائي فقط.**

٥. القياس: بلا تنعيم بلغ أقصى logit 120 بعد 50 حقبة؛ مع تنعيم ($\alpha = 0.1$) بلغ 14.3 $\Longrightarrow$ بُعدٌ آمن عن عتبة fp32 (88.7) وعن عتبة fp16 بفرقٍ بسيط.

النتيجة: تنعيمُ التسمية خفّض أقصى logit من 120 (فيضان fp32 إلى 14.3 — أي أنّه علاجٌ **عدديّ** فعّال لمشكلة الفيضان.

الربط بالذكاء الاصطناعي: هذا يُظهر أنّ كثيراً من «حِيَل التنظيم» لها أثرٌ عددي مباشر: تنعيم التسمية، قصّ التدرّج، تطبيع الأوزان، وتنظيم الإنتروبيا — كلها تحدّ من مدى الـ logits $\Longrightarrow$ تمنع الفيضان وتحسّن الاستقرار الرقمي.

مثال (15-7.6): قصّ التدرّج مع الدقة المختلطة — ترتيب العمليّات يهمّ

المعطيات: تدريب مختلط الدقة: GradScaler بـ $s = 32768$، وقصّ تدرّج بناظم أقصى 1.0 (clip_grad_norm_). التدرّجات الخام $\|g\| = 2.4 \times 10^{-4}$.

الحل:

١. **الترتيب الصحيح** (في كل الأطر): (1) فكّ القياس أولاً (scaler.unscale_(optimizer)) $\Longrightarrow$ $g = \frac{1}{s}\mathrm{fl}(sg)$؛ (2) ثم القصّ؛ (3) ثم تحديث الأوزان؛ (4) ثم scaler.step() الذي يتحقّق من inf/NaN.

٢. لماذا؟ لو قصصنا **قبل** فكّ القياس: المعيار 1.0 يُطبَّق على تدرّجاتٍ مُقيَّسة ($s\|g\| = 7.9$) $\Longrightarrow$ القصّ إلى 1.0 $\Longrightarrow$ بعد فكّ القياس $\|g\| = 3.05 \times 10^{-5}$ $\Longrightarrow$ **قصٌّ مفرط بـ** $\times 8000$ $\Longrightarrow$ التدريب يتوقّف فعلياً.

٣. الحساب الصحيح: $\|g\| = 2.4 \times 10^{-4} < 1.0$ $\Longrightarrow$ **لا قصّ** $\Longrightarrow$ التحديث كما هو.

٤. التحقّق من الفيضان: هل $s\|g\| = 32768 \times 2.4 \times 10^{-4} = 7.87 < 65504$؟ نعم ✓ $\Longrightarrow$ لا فيضان $\Longrightarrow$ يمكن رفع s إلى $2^{18} = 262144$ (لأنّ $262144 \times 2.4 \times 10^{-4} = 62.9 < 65504$) $\Longrightarrow$ دقّة أفضل في التمثيل.

٥. القاعدة التكيفية: $s_{\text{opt}} = \frac{\Omega}{2\|g\|} = \frac{65504}{2 \times 2.4 \times 10^{-4}} = 1.36 \times 10^{8}$ نظرياً — لكن يُحدّ بـ «أكبر قوة من 2 دون حدوث فيضان» $\Longrightarrow$ $s = 2^{18}$.

النتيجة: ترتيبٌ خاطئ واحد (القصّ قبل فكّ القياس) يُبطئ التعلّم بـ $\times 8000$ صامتاً — دون أيّ رسالة خطأ.

الربط بالذكاء الاصطناعي: هذا مثالٌ كلاسيكي على أنّ **أخطاء الدقة المختلطة صامتة:** لا NaN ولا استثناء — بل تدريبٌ «يعمل» لكنه لا يتعلّم. القاعدة: **راقب معيار التدرّج ونسبة التحديث إلى الوزن، لا الفقد وحده.**

7.7.6 أخطاء شائعة

الخطأ الشائع	لماذا هو خطأ	الصواب
$\log(\text{softmax}(z))$	softmax قد يُنتج 0 $\Longrightarrow$ -inf = log(0)	$z - \text{LSE}(z)$ = log_softmax(z)
softmax بلا إزاحة	فيضان/انهيار $\Longrightarrow$ NaN	اطرح $\max z$ أو استعمل الدوال المكتبية
softmax بـ fp16 خالص	عتبة 11.09 أدنى من مدى logits الانتباه	fp32 لـ softmax أو إزاحة متصلة
القصّ قبل فكّ قياس الفقد	قصّ مفرط بـ $s\times$	فكّ القياس $\Longrightarrow$ قصّ $\Longrightarrow$ تحديث
ترك s ثابتاً	إمّا فيضان أو ضياع تدرّجات	s تكيفي: ضاعف عند النجاح، نصف عند NaN
حفظ حالة آدم بـ fp16	انهيار العزم الثاني $\Longrightarrow$ قفزة التحديث	حالة المُحسّن والأوزان الرئيسية بـ fp32
حساب الاحتمالات ثم ضربها في سلسلة طويلة	انهيار إلى صفر	اجمع اللوغاريتمات
الاعتقاد أن fb16 «أفضل» دائماً	أدقّ بـ $8\times$ أقلّ من fp16	fb16 للمدى/الاستقرار، fp16 للدقّة بمدى مضبوط

مجموعة (أ) — التكييف وقانون الحالة الأساسي (8.6)–(13.6)

١. **رقم حالة الجمع.** ليكن $f(x) = x + c$. احسب $\text{cond}(f, x)$ وفسّر النتيجة. < $\text{cond} = \frac{|x\cdot 1|}{|x+c|} = \frac{|x|}{|x+c|}$ $\Longrightarrow$ كبير إذا كان $x + c \approx 0$ (الإلغاء بعينه).

١. **رقم حالة الضرب.** ليكن $f(x, y) = xy$. بيّن أن $\text{cond} = 1$ لكلٍّ من x و y. < $\frac{|xf_x|}{|f|} = \frac{|x\cdot y|}{|xy|} = 1$ $\Longrightarrow$ الضرب لا يضخّم الأخطاء النسبية.

١. **رقم حالة اللوغاريتم.** احسب $\text{cond}(\ln x, x)$ واستنتج متى يكون حساب ln خطيراً. < $\text{cond} = \frac{|x\cdot(1/x)|}{|\ln x|} =$ $\frac{1}{|\ln x|}$ $\Longrightarrow$ كبير حين $x \approx 1$ $\Longrightarrow$ استعمل log1p على $x - 1$.

١. **خانات مفقودة.** إذا كان $\kappa(A) = 3.2 \times 10^5$، فكم خانةً نفقد في fp64 وفي fp32؟ < $\log_{10}(3.2 \times 10^5) =$ $\Longrightarrow$ 5.51 :fp64 يبقى 10.5؛ :fp32 يبقى 1.5.

١. **حدود الدقّة.** ما أكبر κ يمكن تحمّله في fp64 بحيث يبقى رقمٌ صحيح واحد على الأقل؟ < نحتاج $\kappa u < 0.1$ $\Longrightarrow$ $\kappa < 9 \times 10^{14}$.

١. **المسافة إلى المفردية.** إذا كان $\|A\|_2 = 6.4$ و $\kappa_2(A) = 1.28 \times 10^4$، فما بعدُ A عن أقرب مصفوفة مفردة؟ < $\sigma_{\min} = \|A\|_2/\kappa = 5 \times 10^{-4}$.

١. **تضخّم مزدوج.** ليكن A بـ $\kappa = 10^3$ و B بـ $\kappa = 10^4$. ما حدُّ $\kappa(AB)$؟ وهل الحدُّ مُحقَّق؟ < من (12.6): $\kappa(AB) \le 10^7$، مُحقَّق إذا اصطفّت الاتجاهات (مثال: $A = \text{diag}(1, 10^{-3})$، $B = \text{diag}(1, 10^{-4})$ $\Longrightarrow$ $\kappa(AB) = 10^7$).

١. **تطبيق على الشبكات.** شبكة من 20 طبقة بـ $\|W_k\|_2 = 1.05$. كم يبلغ ناظم اليعقوبية الكلّية؟ < $1.05^{20} =$ $\Longrightarrow$ 2.65 تضخّم $2.65\times$ فقط، لكن بـ $\|W\|_2 = 1.3$: $1.3^{20} = 190$.

مجموعة (ب) — الإلغاء والتراكم (14.6)–(19.6)

١. **معامل التضخّم.** احسب معامل التضخّم لطرح $a = 1.0000001$ و $b = 1.0000000$ في fp32. < $\frac{|a|+|b|}{|a-b|} =$ $\Longrightarrow$ خطأ نسبي $\frac{2}{10^{-7}} = 2 \times 10^7 \le 2 \times 10^7 \times 5.96 \times 10^{-8} = 1.19$ (119%).

١. **الصيغة البديلة.** أعد كتابة $\sqrt{x^2+1} - x$ بصيغةٍ خاليةٍ من الطرح. < $\frac{1}{\sqrt{x^2+1}+x}$ $\Longrightarrow$ آمنة لكل $x > 0$.

١. **حدّ الجمع.** احسب γ_n لـ $n = 10^4$ في fp32 وهل الحدّ مفيد؟ < $\gamma_{10^4} = \frac{10^4 \times 5.96\times10^{-8}}{1-5.96\times10^{-4}} = 5.97 \times 10^{-4}$ ⟹ خطأ نسبي في المجموع حتى 0.06%.

١. **كاهان مقابل العادي.** أيّهما تختار على GPU ولماذا؟ < الجمع الشجري (pairwise) — لأنّه متوازٍ وحدّه $u\lceil\log_2 n\rceil$؛ كاهان متسلسل فيقتل التوازي.

١. **ويلفورد.** استعمل (19.6) لحساب متوسط وتباين المتتالية 2, 4, 4, 4, 5, 5, 7, 9 خطوةً بخطوة. < $\bar{x} = 5$؛ $S_8 = \sum(x_i-5)^2 = 9+1+1+1+0+0+4+16 = 32$ ⟹ $s^2 = 32/7 = 4.571$.

١. **كشفُ إلغاء.** كيف تكتشف إلغاءً كارثياً في برنامجك بلا معرفة القيمة الصحيحة؟ < قارن $|a-b|$ بـ $\max(|a|,|b|)$: إن كان أصغر بمراتب عديدة ⟹ أعد الصياغة، أو أعد الحساب بدقة مضاعفة وقارن.

١. **ترتيب الجمع.** رتّب هذه الكميات تصاعدياً قبل جمعها في fp32: $10^8,\ 1,\ 1,\ 1,\ -10^8$ < $+1+1+1-10^8+10^8 = 3$ تصاعدياً مقابل صفر بالترتيب المعطى (لأنّ 10^8+1 يمتصّ الواحد).

١. **expm1.** احسب $e^{10^{-6}}-1$ بـ fp32 بالطريقتين وفسّر. < مباشرةً: $\mathrm{fl}(1.000001) = 1.0000009537$ ⟹ الفرق 9.54×10^{-7} (4.6% خطأ)؛ expm1 يعطي 1.0000005×10^{-6} بخطأ $\approx u$.

مجموعة (ج) — التحويلات المتعامدة و QR (20.6)–(25.6)

١. **بناء هاوسهولدر.** ابتعِث H التي تُحوّل $x = (3,4)^\top$ إلى $(\pm5,0)^\top$. < $\sigma = -\mathrm{sign}(3)\cdot 5 = -5$؛ $v = x-\sigma e_1 = (8,4)^\top$؛ $H = I - \frac{2vv^\top}{80} = \begin{pmatrix}-0.6 & -0.8\\ -0.8 & 0.6\end{pmatrix}$؛ $Hx = (-5,0)^\top$ ✓.

١. **لماذا الإشارة؟** ماذا يحدث لو اخترنا $\sigma = +5$ في التمرين السابق؟ < $v = (3,4)-(5,0) = (-2,4)$ ⟹ $\|v\|^2 = 20$ — لا مشكلة هنا، لكن لو كان $x = (5,0.001)$ فإنّ $v = (0,0.001)$ ⟹ $v^\top v = 10^{-6}$ ⟹ تضخّم هائل. (في حالتنا $\sigma = +5$ يعمل لكنّ القاعدة العامة آمنة.)

١. **تعامد Q.** بيّن أن $\kappa_2(Q) = 1$ لأي مصفوفة متعامدة Q. < $\|Q\|_2 = 1$ و $\|Q^{-1}\|_2 = \|Q^\top\|_2 = 1$ ⟹ $\kappa = 1$.

١. **حفظ الناظم.** بيّن أن $\|QA\|_F = \|A\|_F$ باستعمال الأثر. < $\|QA\|_F^2 = \mathrm{tr}(A^\top Q^\top QA)$ $= \mathrm{tr}(A^\top A) = \|A\|_F^2$.

١. **MGS مقابل هاوسهولدر.** إذا كان $\kappa(A) = 10^{10}$ و $n = 100$ بـ fp64، فما فقدانُ التعامد المتوقّع لكلٍّ منهما؟ < MGS: $\approx 100\times1.11\times10^{-16}\times10^{10} = 1.11\times10^{-4}$؛ هاوسهولدر: $\approx 1.11\times10^{-14}$ ⟹ فرق $\times10^{10}$.

١. **اختبار الاستقرار الخلفي.** حللتَ نظاماً فوجدتَ الباقي النسبي 4.2×10^{-12} بـ fp64. ماذا تستنتج؟ < $\eta \gg u$ ⟹ الخوارزمية **غير** مستقرّة خلفياً (مع افتراض ρ و κ معقولين).

مجموعة (د) — المربعات الصغرى والتحليل المباشر (26.6)–(37.6)

١. **تربيع رقم الحالة.** إذا كان $\kappa_2(X) = 250$، فما $\kappa_2(X^\top X)$ وكم خانةً نفقد بالمعادلات السوية في fp32؟ > 6.25×10^4 ⟹ خانات مفقودة 4.80 ⟹ يبقى 2.2 خانة.

١. **حدّ الباقي.** متى يصير حدّ κ^2 في (27.6) هو المهيمن؟ > حين $\frac{1}{\kappa} > \frac{\|r\|}{\|A\|\|x\|}$ أي حين يكون الباقي «كبيراً» نسبياً؛ أي $\tan\theta \gtrsim 1/\kappa$.

١. **ريدج.** ما λ التي تضمن ألّا يتجاوز تضخيم الضوضاء ×10؟ > من (30.6): $\frac{1}{2\sqrt{\lambda}} \le 10 \Longrightarrow \lambda \ge 2.5 \times 10^{-3}$.

١. **مصفوفة ويلكنسون.** ما عامل النموّ للحدّ الأسوأ بـ $n = 10$؟ > $\rho = 2^9 = 512$.

١. **شوليسكي.** لماذا $\rho = 1$ لشوليسكي على مصفوفة موجبة التعريف؟ > لأن $|r_{ij}|^2 \le r_{ii} r_{jj} \le \max_i a_{ii}$ ⟹ لا يمكن أن تنمو العناصر عن جذر أكبر عنصر قطري.

١. **التنقيح.** متى يتقارب التنقيح التكراري بعوامل fp32 وباقي fp64؟ > إذا كان $c\,u_{32}\,\rho\,\kappa(A) < 1$؛ أي تقريباً $\kappa\rho < 1.7 \times 10^7$.

١. **المعكوس الصريح.** لماذا solve(A,b) أفضل من inv(A)@b؟ > inv يكلّف $\approx 3\times$ أكثر ويحمل خطأً أعلى (الخطأ الخلفي للمعكوس الصريح لا يُترجَم إلى خطأٍ خلفي صغير للحلّ).

١. **التقييس.** مصفوفةٌ عناصرها بين 10^{-6} و 10^{6}. ما أوّلُ خطوة قبل التحليل؟ > تقييسُ الصفوف/الأعمدة (equilibration) ⟹ يخفض κ و ρ معاً قبل أيّ تدوير أو تنقيح.

1.9.6 جدول النظريات الست

النظرية	الصيغة الحاكمة	الأثر في الذكاء الاصطناعي
الأساسي	forward $\lesssim \kappa \times$ backward، خانات مفقودة $\log_{10}\kappa$ (8.6)–(13.6)	لا خوارزمية تتجاوز رقم الحالة؛ التنظيم والتطبيع علاجاتٌ «لتكييف» لا «للدقة»
والتراكم	γ_n، كاهان $2u$ (14.6)–(19.6)، $\frac{\lvert a\rvert+\lvert b\rvert}{\lvert a-b\rvert}u$	التباين، الفروق الصغيرة، تراكم التدرّجات: كلها تحتاج صياغةً خاليةً من الطرح وتراكماً بدقة أعلى
المتعامدة	$A+\Delta A=\hat{Q}\hat{R}$، $\lVert\Delta A\rVert \le cmnu\lVert A\rVert$، $\kappa(Q)=1$ (20.6)–(25.6)	التهيئة المتعامدة، التطبيع الطيفي، المحسّنات الحافظة للناظم، QR في كل مكان
الصغرى	$\kappa(A^\top A)=\kappa(A)^2$، حدّ غولوب–ويلكنسون (26.6)–(31.6)	لا تشكّل مصفوفات الغرام/التغاير؛ ريدج $\frac{1}{2\sqrt{\lambda}} \le$ تضخيماً
في LU	$\rho \le 2^{n-1}$، خطأ خلفي $cnu\rho$، التنقيح (32.6)–(37.6)	التنظيم يجعل المصفوفات SPD ⟹ شوليسكي بلا تدوير؛ التنقيح المختلط = دقة fp64 بسرعة fp16
softma	$z - \mathrm{LSE}$، $m + \log\sum e^{z_i - m}$، قياس الفقد (38.6)–(44.6)	العملُ في فضاء اللوغاريتم؛ الدقة المختلطة صامتة الأخطاء ⟹ راقب النواظم لا الفقد

2.9.6 المبادئ الستة الحاكمة

١. **التكييفُ سمةُ المسألة، والاستقرارُ سمةُ الخوارزمية.** لا تُصلح الأول بالثاني.

٢. **الخانات المفقودة $= \log_{10}\kappa$.** احسبها قبل أن تصدّق أي رقم.

٣. **الطرحُ أخطرُ من أي عملية أخرى.** ابحث عن صياغةٍ بلا طرح قبل أن تزيد الدقّة.

٤. **التراكمُ يجب أن يكون بدقة أعلى من الحساب.** (أوزان رئيسية، مُجمّعات، fp32 حالة مُحسّن fp32.)

٥. **البنيةُ تُحدّد الاستقرار قبل حجم κ.** SPD $\Longrightarrow$ شوليسكي ($\rho = 1$)؛ مهيمنة قطرية $\Longrightarrow$ بلا تدوير؛ متعامد $\Longrightarrow$ بلا تضخيم.

٦. **اعمل في فضاء اللوغاريتم.** كل حسابٍ احتمالي طويل ينجو بالانتقال إلى log.

3.9.6 الطريق إلى ما بعد هذا الفصل

تمّ الجزء الأول. في الجزء الثاني (التفاضل والتكامل) ننتقل من «كيف نحسب بأمان» إلى «كيف تتغيّر الكميات»: النهايات والاتصال والتقارب، ثم الاشتقاق والاشتقاق الآلي (وهو — بفضل هذا الفصل — نفهمه الآن كـ «سلسلة من عمليات مستقرّة عددياً»، لا كصندوق أسود)، ثم التفاضل المصفوفي واليعقوبية والهِسّية، ثم التكامل ونظرية القياس، ثم متفاضلة تايلور التي تُتوّج تحليل الأخطاء، ثم المعادلات التفاضلية التي سنقرأ بها لاحقاً نماذجَ الانتشار (dffiusion models) قراءةً رياضية دقيقة.

الرمز	المعنى	أوّل ظهور
$\mathrm{fl}(\cdot)$	دالة التقريب إلى أقرب عدد مُمثَّل	(1.6)
u	وحدة التقريب (unit roundoff) $= \frac{1}{2}\beta^{1-t}$	(2.6)
β, t	أساس التمثيل وعدد خانات الجوهر	(2.6)
$\varepsilon_{\text{machine}}$	الفجوة الكاملة $\beta^{1-t} = 2u$ (اصطلاح بديل)	1.1.6§
Ω, ω	أكبر/أصغر عدد مُمثَّل	(44.6)، 1.1.6§
δ, δ_i	خطأ التقريب في عملية واحدة، $\|\delta\| \le u$	(1.6)
$e_{\text{abs}}, e_{\text{rel}}$	الخطأ المطلق والنسبي	(3.6)
$\hat{x}, \hat{y}$	القيم المحسوبة (المُخزَّنة)	(3.6)
$\Delta x, \Delta y$	الخطأ الخلفي والأمامي	(4.6)
$\mathrm{cond}(f, x)$	رقم الحالة النسبي للمسألة	(5.6)
$\kappa(A), \kappa_2(A)$	رقم حالة المصفوفة، $= \sigma_1/\sigma_{\min}$	(6.6)
γ_n	ثابت التراكم $\frac{nu}{1-nu}$	(7.6)
$\sigma_i, \sigma_1, \sigma_{\min}$	القيم المفردة	(6.6)
a, b	العددان المطروحان (الإلغاء)	(14.6)
$\mathrm{expm1}, \mathrm{log1p}$	دوال مكتبية مستقرّة	(15.6)
$s_n, \hat{s}_n$	المجموع الدقيق والمحسوب	(16.6)
c	متغيّر التعويض (كاهان)	(17.6)
M_k, S_k	المتوسط ومجموع مربّعات الانحرافات الجاريان (ويلفورد)	(19.6)
H, v, σ	مصفوفة هاوسهولدر ومتجه الانعكاس والقيمة المستهدَفة	(20.6)
e_1	متجه الوحدة الأوّل	(20.6)
$\hat{Q}, \hat{R}$	عاملا QR المحسوبان	(21.6)
c_i	ثوابت صغيرة في حدود الخطأ	(21.6)
r	الباقي $b - Ax$	(27.6)
θ, η	زاوية الباقي ومعامل حجم الحلّ	(28.6)
τ	عتبة التجذيع (SVD مبتور)	(29.6)
λ	معامل التنظيم (ريدج/تيخونوف)	(30.6)
f_i	عوامل الترشيح $\frac{\sigma_i^2}{\sigma_i^2+\lambda}$	(30.6)
κ_{LS}	رقم حالة مسألة المربعات الصغرى	(27.6)
P, L, U	التبديل والعاملان في LU	(32.6)
ρ	عامل النموّ (growth factor)	(33.6)
x_k, r_k, d_k	التقدير والباقي والتصحيح في التنقيح التكراري	(36.6)
u_r	وحدة تقريب حساب الباقي	(36.6)
z, m	متجه الـ logits وأكبرها	(38.6)
LSE	log-sum-exp	(39.6)
ℓ_{CE}	فقد الإنتروبيا المتقاطعة	(40.6)
p_i, q_i	احتمال softmax والتوزيع المستهدف	(43.6)، (40.6)
s	معامل قياس الفقد (loss scale)	(44.6)
T	درجة الحرارة في softmax	مثال 8-7.6

١. Higham, N. J. (2002). *Algorithms Numerical of Stability and Accuracy* (2nd ed.). SIAM — المرجع المعياري للتحليل الخلفي وحدود γ_n.

٢. Wilkinson, H. J. (1963). *Processes Algebraic in Errors Rounding*. Prentice-Hall — أصل التحليل الخلفي ومصفوفة ويلكنسون.

٣. Wilkinson, H. J. (1961). Error of analysis numerical of methods direct of inversion. matrix, *J. ACM*, 8(3), 281–330. — حدّ النموّ 2^{n-1}.

٤. Golub, G., & Van Loan, F. C. (2013). *Matrix Computations* (4th ed.). Johns Hopkins. — QR، SVD، LS، التنقيح.

٥. Trefethen, L. N., & Bau, D. (1997). *Numerical Linear Algebra*. SIAM. — هندسة QR وهاوسهولدر.

٦. Björck, Å. (1996). *Numerical Methods for Least Squares Problems*. SIAM. — تكييف المربعات الصغرى وغرام–شميت.

٧. Demmel, W. J. (1997). *Applied Linear Algebra*. SIAM. — شروط الصحّة والحدود العملية.

٨. Golub, G., & Wilkinson, H. J. (1966). Note on the iterative refinement of least squares solutions. *Numer. Math.*, 9, 139–148. — حدّ غولوب–ويلكنسون.

٩. Stewart, G. W. (1977). On the perturbation of pseudo-inverses, projections and linear least squares problems. *SIAM Review*, 19(4), 634–662. — متراجحات ويدين.

١٠. Wedin, P.-Å. (1973). Perturbation theory for pseudo-inverses. *BIT*, 13, 217–232. — اضطراب المعكوس المعمَّم.

١١. Kahan, W. (1965). Further remarks on reducing truncation errors. *CACM*, 8(1), 40. — جمع كاهان.

١٢. Higham, N. J. (1993). The accuracy of floating point summation. *SIAM J. Sci. Comput.*, 14(4), 783–799. — تحليل كاهان والجمع الشجري.

١٣. Wetherford, P. B. (1962). Note on a method for calculating corrected sums of squares and products. *Technometrics*, 4(3), 419–420. — خوارزمية ويلفورد.

١٤. Trefethen, L. N., & Schreiber, R. S. (1990). Average-case stability of Gaussian elimination. *SIAM J. Matrix Anal. Appl.*, 11(3), 335–360. — النموّ العملي $n^{2/3}$.

١٥. Skeel, R. D. (1980). Iterative refinement implies numerical stability for Gaussian elimination. *Math. Comp.*, 35, 817–832. — نتيجة سكيل للتنقيح بدقة ثابتة.

١٦. Moler, C. B. (1967). Iterative refinement in floating point. *J. ACM*, 14(2), 316–321. — التنقيح بدقة مضاعفة.

١٧. Hartley, R. I. (1997). In defense of the eight-point algorithm. *IEEE TPAMI*, 19(6), 580–593. — التطبيع يخفض κ (مثال 6.2-3).

١٨. Björck, Å., & Golub, G. H. (1973). Numerical methods for computing angles between linear subspaces. *Math. Comp.*, 27, 579–594.

١٩. Moler, C. (2004). *Numerical Computing with MATLAB*. SIAM. — أمثلة عملية (فانديرموند، هلبرت).

٢٠. Dongarra, J., Abdelfattah, A., Tomov, S., Gates, M., Kabir, K., Ribizel, T., & Anzt, H. (2019). Accelerating numerical dense linear algebra calculations with GPUs. *Parallel Computing: Accelerators, Embedded Technologies and Applications*, 3–28.

٢١. Haidar, A., Tomov, S., Dongarra, J., & Higham, N. J. (2018). Harnessing GPU tensor cores for fast FP16 arithmetic to speed up mixed-precision iterative refinement solvers. *SC18*. — تنقيح مختلط الدقة (مثال 6.6-15).

٢٢. Micikevicius, P., Narang, S., Alben, J., Diamos, G., Elsen, E., Garcia, D., … Wu, H. (2018). Mixed precision training. *ICLR*. — قياس الفقد والأوزان الرئيسية.

٢٣. NVIDIA (2023). *Automatic Mixed Precision / Transformer Engine Documentation*. — fb16 مقابل fp16، قياس الفقد التكيفي.

٢٤. Dao, T., Fu, D. Y., Ermon, S., Rudra, A., & Ré, C. (2022). FlashAttention: Fast and memory-efficient exact attention with IO-awareness. *NeurIPS*. — softmax بالإزاحة المتصلة (مثال 6.7-3).

٢٥. Pennington, J., Schoenholz, S., & Ganguli, S. (2017). Resurrecting the sigmoid in deep learning through dynamical isometry. *ICLR*. — التهيئة المتعامدة.

٢٦. Miyato, T., Kataoka, T., Koyama, M., & Yoshida, Y. (2018). Spectral normalization for generative adversarial networks. *ICLR*. — التطبيع الطيفي و 1-Lipschitz (مثال 6.4-3).

٢٧. Arjovsky, M., Shah, A., & Bengio, Y. (2016). Unitary evolution recurrent neural networks. *ICML*. — الشبكات المتعامدة (مثال 6.4-11).

٢٨. Yu, F. X., Suresh, A. T., Choromanski, K. M., Holtmann-Rice, D. N., & Kumar, S. (2016). Orthogonal random features. *NIPS*. — ميزات عشوائية متعامدة (مثال 6.4-13).

٢٩. Uhler, C., Lederer, J., Belkin, M., & Rubinstein, A. (2020). On the implicit bias of overparameterized neural networks. *PNAS*. — المربعات الصغرى ناقصة التحديد (مثال 6.5-14).

٣٠. Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *J. Multivariate Anal.*, 88(2), 365–411. — انكماش مصفوفة التغاير (مثال 6.2-11).

تمّ الفصل السادس، وتمّ الجزء الأول من الكتاب. في الجزء الثاني نبدأ **التفاضل والتكامل** — ونعيد قراءة كل ما سبق بمنظور «كيف تتغيّر الكميات»، ابتداءً من النهايات والاتصال والتقارب.

القسم II

التفاضل والتكامل

نبذة عن هذا الجزء

التعلّم الآلي في جوهره فعلٌ تفاضلي: نُغيّر المعاملات قليلاً ونقيس أثرَ ذلك في الخطأ. لذا يفتتح هذا الجزء بوحدة **النهاية والتقارب** — وهي التي تحوّل «قريب» إلى مفهومٍ دقيق — ثم **قواعد التفاضل** وتعميمها الأهم عمليّاً: **التفاضل المصفوفي** الذي تُكتب به صيغ الانتشار العكسي كلّها. بعدها نرتقي إلى **التكامل ونظرية القياس** لنتعامل مع التوقّعات والتوزيعات بصرامة، و**متسلسلة تايلور** لتحليل الخطأ من الدرجة الثانية التي تقوم عليها خوارزميات كوازي-نيوتن، ونختم بـ**المعادلات التفاضلية والأنظمة الحركية** حيث يُنظر إلى انحدار التدرّج نفسه بوصفه مساراً زمنياً متّصلاً. هذا الجزء هو الجسر: يساره هندسة الجزء الأول، ويمينه احتمالات الجزء الثالث وتحسينات الجزء الرابع. **فصول الجزء:** النهايات والاستمرارية والتقارب · قواعد التفاضل · التفاضل المصفوفي · التكامل والقياس · تايلور وتحليل الخطأ · المعادلات التفاضلية والأنظمة الديناميكية.

فصول هذا الجزء

- **الفصل 7.** النهايات والاتصال والتقارب
- **الفصل 8.** الاشتقاق وقواعده
- **الفصل 9.** التفاضل المصفوفي: اليعقوبية، الهِسّية، وقواعد السلسلة
- **الفصل 10.** التكامل، نظرية القياس، وتكامل ليبيسغ–ستيلتjes
- **الفصل 11.** متفاضلة تايلور وتحليل الأخطاء
- **الفصل 12.** المعادلات التفاضلية والنظم الديناميكية

النهايات والاتصال والتقارب

الهدف من الفصل

أول فصول الجزء الثاني (التفاضل والتكامل). بنينا في الجزء الأول العالَمَ الخطّي: المتجهات، المصفوفات، النواظم، والاستقرار العددي. الآن ننتقل إلى العالم اللاخطّي — وهذا هو العالم الحقيقي الذي تعيش فيه الشبكات العصبية: الدوالّ منحنية، والخسائر غير المستقرة، والحدود التي تُقترب إليها خوارزمياتنا من دون أن تصلها.

قبل الغرق في التعريفات، لننظر إلى ثلاثة مواقف من الميدان:

١. **الانحدار التدريجي (Gradient Descent)** هو — في جوهره — تعريف نهاية:

$$x_{k+1} = x_k - \eta \nabla f(x_k), \qquad x^* = \lim_{k \to \infty} x_k$$

السؤال «متى تتقارب الخوارزمية؟» هو حرفياً سؤال «متى توجد هذه النهاية؟». الإجابة تحتاج مفاهيم التقارب التي سنبنيها في هذا الفصل.

١. **دوالّ التنشيط عند النقاط الحرجة:** دالة ReLU:

$$\mathrm{ReLU}(x) = \max(0, x)$$

غير قابلة للاشتقاق عند $x = 0$ بالتعريف الكلاسيكي — لكنّها **متصلة** هناك. لماذا يهتم جسّد الانتشار العكسي؟ لأن الاتصال يكفي لوجود نهاية الفروق المنتهية، والاشتقاق الشائع يستبدل بها الميل الأيسر/الأيمن. هذا التمييز بين «متصل» و«قابل للاشتقاق» هو موضوع هذا الفصل.

١. **دقّة الأعداد العائمة والنهاية:** حسبنا في الفصل السابق أنّ حساب $f(x) = \frac{1-\cos x}{x^2}$ مباشرةً عند $x = 10^{-8}$ يعطي 0 في fp64 بسبب الإلغاء، بينما النهاية الحقيقية $\frac{1}{2} =$. أي أنّ **النهاية رياضية المفهوم، والعدّة عددية المفهوم** — والفجوة بينهما هي بالضبط علم التحليل العددي الذي مهدناه.

خريطة الفصل

القسم	الموضوع	الأداة الأساسية
2.7	تعريف النهاية (ϵ–δ) والنهايات الأحادية	الرسمي ϵ–δ
3.7	قوانين النهايات وحالات عدم التعيين	الجبر
4.7	الاتصال (الاستمرارية) وأنواع الانقطاع	ϵ–δ عند نقطة
5.7	نظريات القيم الوسطى والبولزانو–فايرشتراس	وجود الجذور
6.7	التقارب المتسلسلي: النهايات والتقارب	حدّية المتتاليات
7.7	التقارب الوظيفي: النقطة مقابل التوحيد	تبديل النهايات
8.7	تطبيقات متقدّمة: من ϵ–δ إلى التعلم الآلي	تجميع

الحدس

نكتب $\lim_{x\to a} f(x) = L$ إذا كانت قيم f تُقترب إلى L كلّما اقترب x من a **من دون بلوغه.** الكلمتان الحاسمتان: «تُقترب» (قابلة للقياس!) و«من دون بلوغه» (لا يهمّنا ما قيمة $f(a)$ أصلاً).

التعريف الرسمي (Weierstrass)

dir="ltr"> <div
ffi: $\lim_{x\to a} f(x) = L$ **(Limit). 1.2.7 Definition**

$$\forall \varepsilon > 0 \;\; \exists \delta > 0 : \quad 0 < |x - a| < \delta \implies |f(x) - L| < \varepsilon.$$

معادلة مُعلَّمة:

$$\forall \varepsilon > 0 \; \exists \delta > 0 : \; 0 < |x - a| < \delta \Rightarrow |f(x) - L| < \varepsilon \tag{1.7}$$

جدول الرموز

الرمز	الاسم	المعنى الدقيق
ε	الإبسيلون (دقّة الخرج)	أقصى خطأ مسموح في $f(x)$ حول L
δ	الدلتا (نصف قطر المدخل)	مدى الاقتراب المسموح بـ x من a
$0 < \|x-a\|$	الاستثنائية	نستثني النقطة a نفسها
$\forall/\exists$	الكمّيات	«لكل» هدية من الخصم، «يوجد» ما نقدّمه

ملاحظة لغوية مهمّة:

في «اللعبة» الكمّي $\forall\varepsilon$ **خصمُنا** — يختار دقّة صغيرة مهما كانت — ونحن نردّ بـ δ تناسبها. إن وجدنا δ لكل ε فازَ التعريف؛ إن فشل الخصم في ε واحدة، انهار الادّعاء.

رسم توضيحي

<figure> الشكل<figcaption> 1.7: لعبة ϵ–δ — لكل شريط أفقي حول L بسماكة 2ε نجد شريطاً عمودياً حول a بسماكة 2δ تُسقط فيه الرسم كلّه (عدا ربما النقطة a) داخل الشريط الأفقي.</figcaption> </figure>

برهان نموذجي (الطريقة)

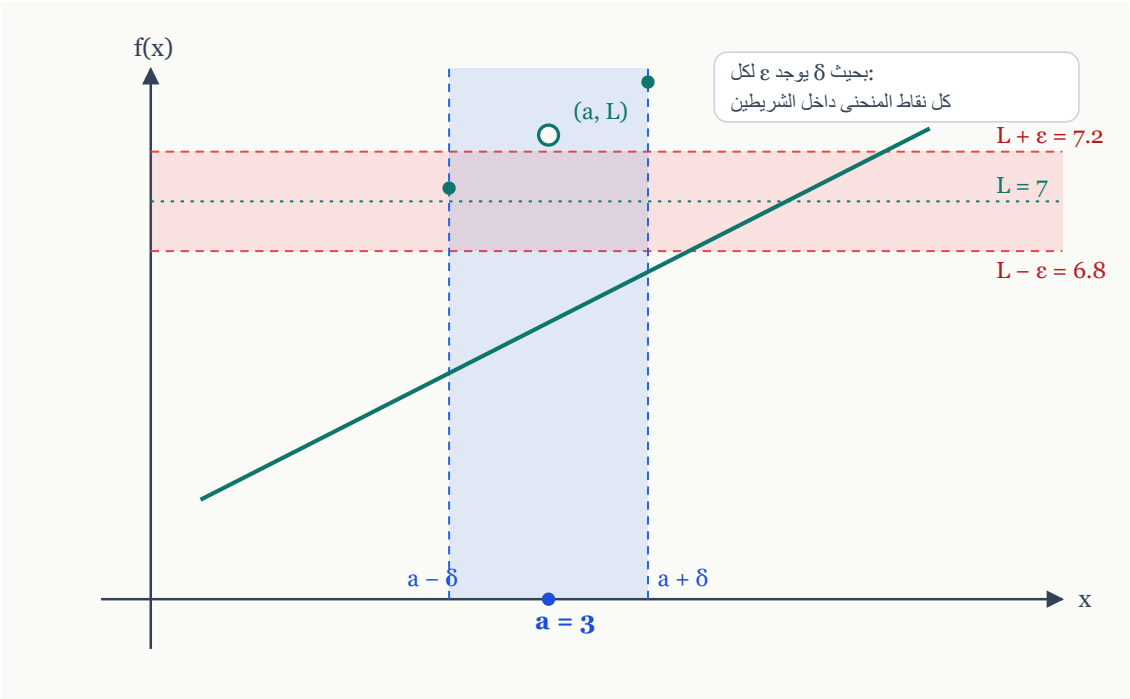
النظرية 1.2.7. $\lim_{x\to 3}(2x+1) = 7$.

البرهان.

لكل $\varepsilon > 0$ اختَر $\delta = \varepsilon/2$. حينها:

$$|x-3| < \delta \implies |(2x+1)-7| = 2|x-3| < 2\cdot\frac{\varepsilon}{2} = \varepsilon. \qquad \blacksquare$$

لاحظ البنية التي سنكرّرها 15 مرة: **عالج $|f(x)-L|$ جبرياً حتى تفصل $|x-a|$، ثم اختر δ بدلالة ε.**



شكل ١٠٧: *
تعريف ϵ–δ للنهاية

أخطاء شائعة في تعريف ϵ–δ

الخطأ	لماذا خطأ	التصحيح
«النهاية هي قيمة $f(a)$»	التعريف يستثني a؛ قد لا تكون f معرّفة أصلاً عندها	النهاية سلوكٌ قربَ النقطة لا عندها
اختيار δ ثابتاً لا يعتمد على ε	الخصم يصغّر ε فينهار	δ دالة في ε (غالباً خطية أو تربيعية)
$0 < \|x-a\| < \delta$ بدل $\|x-a\| < \delta$	يُدرج النقطة نفسها	دائماً استثنِ a في النهايات
«يجب أن يكون δ أكبر ما يمكن»	يكفي وجود δ واحد صالح	أيّ δ أصغر من الموجود صالحٌ أيضاً

أمثلة محلولة على تعريف ϵ–δ (15 مثالاً)

مثال (1-2.7).

- **المعطيات:** $f(x) = 5x - 2$، والنقطة $a = 1$.
- **المطلوب:** برهن أنّ $\lim_{x \to 1} f(x) = 3$ بتعريف ϵ–δ.
- **الحل:**

١. نعالج الفرق: $|f(x) - 3| = |5x - 2 - 3| = 5|x - 1|$.

٢. لكل $\varepsilon > 0$ نختار $\delta = \varepsilon/5$.

٣. حينها $0 < |x-1| < \delta \Rightarrow |f(x) - 3| < 5 \cdot \varepsilon/5 = \varepsilon$. ■

- **النتيجة:** النهاية 3، و $\delta(\varepsilon) = \varepsilon/5$ خطية.

- **الربط بالذكاء الاصطناعي:** هذا «الميل» في المثال 1.2.7 هو نفسه مشتقّ $f'(1) = 5$؛ لكل دوال التنشيط الخطية يقاس δ بمعامل الميل.

مثال (2-2.7).

- **المعطيات:** $f(x) = x^2$، $a = 2$.
- **المطلوب:** برهن أنّ $\lim_{x \to 2} x^2 = 4$.
- **الحل:**

١. $|x^2 - 4| = |x - 2|\,|x + 2|$.

٢. نقيد: إن كانت $|x - 2| < 1$ فإنّ $1 < x < 3$ إذن $|x + 2| < 5$.

٣. نختار $\delta = \min(1, \varepsilon/5)$، حينها $|x^2 - 4| < 5\delta \le \varepsilon$. ■

- **النتيجة:** $\delta = \min(1, \varepsilon/5)$ — التقيد المسبق تقنية قياسية.
- **الربط بالذكاء الاصطناعي:** الدوالّ التربيعية تظهر في حدّية النواة $L \le \beta L_0$ (إلغاء التدرّج)؛ التقيد بجوار النقطة يضمن الحدّية موضعيّاً — نفس الفكرة في براهين التقارب المحلي لـ Adam.

مثال (3-2.7).

- **المعطيات:** $f(x) = \dfrac{1}{x}$، $a = 2$.
- **المطلوب:** برهن أنّ $\lim_{x \to 2} \frac{1}{x} = \frac{1}{2}$.
- **الحل:**

١. $\left|\frac{1}{x} - \frac{1}{2}\right| = \frac{|x-2|}{2|x|}$.

٢. تقيد $|x - 2| < 1 \Rightarrow x > 1 \Rightarrow 2|x| > 2 \Rightarrow \frac{1}{2|x|} < \frac{1}{2}$.

٣. نختار $\delta = \min(1, \varepsilon)$، إذن الفرق $< \delta < \varepsilon$. ■

- **النتيجة:** النهاية $1/2$ بـ $\delta = \min(1, \varepsilon)$.
- **الربط بالذكاء الاصطناعي:** الدوالّ المتناسبة عكسياً تظهر في معدّل التعلّم $\eta = \alpha/k$؛ الاقتراب إلى 0 (نهاية عند اللانهاية) يحكمها تقدير مشابه.

مثال (4-2.7).

- **المعطيات:** $f(x) = |x|$، $a = 0$.
- **المطلوب:** برهن أنّ $\lim_{x \to 0} |x| = 0$ رغم أنّ f غير قابلة للاشتقاق هناك.

- **الحل:**

١. $||x| - 0| = |x|$.

٢. اختر $\varepsilon = \delta$، إذن $|x| < \delta = \varepsilon$. ■

- **النتيجة:** النهاية موجودة $= 0$؛ لكن الميل الأيسر $= -1$ والأيمن $= +1 \Longrightarrow$ لا مشتقّ.

- **الربط بالذكاء الاصطناعي:** ReLU عند الصفر: نهاية موجودة، اشتقاق لا. لذلك pytorch يستخدم subgradient فيرتّع إلى 0 أو 1 بحسب التنفيذ.

مثال (7.2-5).

- **المعطيات:** دالة الإشارة $\operatorname{sgn}(x) = \begin{cases} 1 & x > 0 \\ 0 & x = 0 \\ -1 & x < 0 \end{cases}$

- **المطلوب:** هل $\lim_{x\to 0} \operatorname{sgn}(x)$ موجودة؟

- **الحل:**

١. النهاية اليمنى: $x \to 0^+ \Rightarrow \operatorname{sgn} = 1$.

٢. النهاية اليسرى: $x \to 0^- \Rightarrow \operatorname{sgn} = -1$.

٣. $\varepsilon = \frac{1}{2}$: مهما صغّرنا δ تبقى قيم من الطرفين تُخرق $|f(x) - L| < \frac{1}{2}$ لأيّ L. ■

- **النتيجة:** النهاية **غير موجودة** (النهايتان الأحاديتان مختلفتان).

- **الربط بالذكاء الاصطناعي:** عتبة التصنيف الثنائي عند $\hat{y} = \mathbb{1}[\sigma(z) > \frac{1}{2}]$ لها نفس السلوك المتقطّع؛ لذلك ندرّب بالدوالّ الناعمة (sigmoid) ونعومِن (softening) عند الاستدلال.

مثال (7.2-6).

- **المعطيات:** $f(x) = \dfrac{\sin x}{x}$.

- **المطلوب:** برهن هندسياً أنّ $\lim_{x\to 0} \frac{\sin x}{x} = 1$.

- **الحل:**

١. للمقارنة في الربع الأول: $\sin x < x < \tan x$.

٢. القسمة على $\sin x$: $1 < \dfrac{x}{\sin x} < \dfrac{1}{\cos x}$.

٣. بالمعكوس: $\cos x < \dfrac{\sin x}{x} < 1$، وبما أنّ $\cos x \to 1$ فبحلقة القص (لاحقاً 5.7) النهاية $= 1$. ■

- **النتيجة:** $\lim_{x\to 0}\frac{\sin x}{x}=1$ — واحدة من أهمّ النهايات المرجعية.

- **الربط بالذكاء الاصطناعي:** GELU: $\mathrm{GELU}(x)=x\,\Phi(x)\approx\frac{x}{2}\left[1+\tanh\!\left(\sqrt{2/\pi}(x+0.0447x^3)\right)\right]$؛ تحليل سلوكها القرب من الصفر يستخدم هذا الحدّ (ذات الحدين $\sin x\approx x$).

مثال (7-2.7).

- **المعطيات:** $f(x)=e^{-1/x^2}$ مع تعريف $f(0)=0$.
- **المطلوب:** برهن أنّ $\lim_{x\to 0}f(x)=0$.
- **الحل:**

١. لكل $\varepsilon>0$: $e^{-1/x^2}<\varepsilon \iff -1/x^2<\ln\varepsilon \iff x^2<\frac{-1}{\ln\varepsilon}$ (للـ $\varepsilon<1$).

٢. نختار $\delta=\sqrt{\dfrac{-1}{\ln\varepsilon}}$.

٣. حينها $|x|<\delta\Rightarrow f(x)<\varepsilon$. ■

- **النتيجة:** النهاية 0، هذه «الدالة المسطّحة» الشهيرة.

- **الربط بالذكاء الاصطناعي:** هذه الدالة متصلة (بل سلسة!) عند 0 لكنّ كل اشتقاقها أعلى فيها 0 — نموذج «الوادي المسطّح» الذي يُربِك محسّنات التدرّج ويقود لمنهجيات Sharpness-Aware Minimization.

مثال (8-2.7).

- **المعطيات:** $f(x)=\dfrac{x^2-1}{x-1}$.
- **المطلوب:** $\lim_{x\to 1}f(x)$ مع أنّ $f(1)$ غير معرّفة.
- **الحل:**

١. $x\neq 1$ إذن $f(x)=x+1$ (اختزال جبري مسموح لأنّ التعريف يستثني a).

٢. النهاية $=2$.

٣. قيمة $f(1)$ لا تدخل في التعريف أصلاً. ■

- **النتيجة:** النهاية $2=$ رغم عدم التعريف عند النقطة.

- **الربط بالذكاء الاصطناعي:** «الثقب القابل للاختزال» هو نفسه حالة $y=\hat{y}-\hat{y}$ الناتجة عن قناع softmax الداخلي؛ نُعيد تعريف الدالة عند النقطة لنسدّ الثقب دون تغيير السلوك القرب.

مثال (7.2-9).

- **المعطيات:** $f(x) = x \sin \frac{1}{x}$ (مع $f(0)$ غير معرّفة).
- **المطلوب:** برهن $\lim_{x \to 0} f(x) = 0$ (نظرية الضغط/الحصر).
- **الحل:**

١. $-|x| \leq x \sin \frac{1}{x} \leq |x|$ لأنّ $\left|\sin \frac{1}{x}\right| \leq 1$.

٢. الطرفان $\to 0$، فبالحصر الوسط $\to 0$. ■

- **النتيجة:** النهاية 0 بالحصر بين دالّتين.

- **الربط بالذكاء الاصطناعي:** «التذبذب السريع المضبوط بِسوَار» هو صورة التدرّجات الثابتة الاتجاه على الدُفعات (batch) التي يتلاشى حجمها كـ $O(\sqrt{k})$ بينما النشاز (noise) يتلاشى أسرع.

مثال (7.2-10).

- **المعطيات:** $f(x) = \begin{cases} x + 1 & x < 2 \\ 5 - x & x > 2 \end{cases}$
- **المطلوب:** النهايات الأحادية وحدد وجود النهاية.
- **الحل:**

١. يساراً: $\lim_{x \to 2^-} (x + 1) = 3$.

٢. يميناً: $\lim_{x \to 2^+} (5 - x) = 3$.

٣. تساويَا $\Longrightarrow$ النهاية $= 3$. ■

- **النتيجة:** النهاية موجودة $= 3$ (الدالة إبرّة بقمة عند 2 إذا عرّفنا $f(2) = 3$).

- **الربط بالذكاء الاصطناعي:** دالة الخسارة ReLU المركّبة «إبرّة» مشابهة عند قيم الشبكة الحرجة؛ الاتصال يكفي لتعريف الشبه-اشتقاق (Clarke) المستخدم في محسّنات التدرّج المتقطّع.

مثال (7.2-11).

- **المعطيات:** $f(x) = \begin{cases} 1 & x \in \mathbb{Q} \\ 0 & x \notin \mathbb{Q} \end{cases}$ (دالة ديريشليه).
- **المطلوب:** أين توجد النهاية؟

- **الحل:**

١. عند أيّ a: في كل جوار δ يوجد عددين ونسبيّ.

٢. اخترنا L أيّ ما كان: $\varepsilon = \frac{1}{3}$ تفشل لأنّ قيمتين تختلفان بمقدار 1 داخل الجوار.

٣. إذن النهاية لا توجد عند أي نقطة. ■

- **النتيجة:** دالة ديريشليه بلا نهايات في أي مكان.

- **الربط بالذكاء الاصطناعي:** تذكير بأنّ «متصلة في كل نقطة» ليست بديهية؛ الشبكات العصبية ذات التنشيط المستمر (ReLU/ELU/GELU) متصلة تعريفياً — وهذه خاصية نستثمرها في براهين الشمول العالمي.

مثال (12-2.7).

- **المعطيات:** $f(x) = \sqrt{x}$ عند $a = 0$.
- **المطلوب:** النهاية اليمنى بتعريف ϵ–δ.
- **الحل:**

١. لكل $\varepsilon > 0$: $0 \le x < \varepsilon^2 \iff |\sqrt{x} - 0| < \varepsilon$.

٢. نختار $\delta = \varepsilon^2$ (ونقيّد المجال $x \ge 0$). ■

- **النتيجة:** $\lim_{x \to 0^+} \sqrt{x} = 0$.

- **الربط بالذكاء الاصطناعي:** دوال الجذر (RMSNorm) لها نهاية يمينية عند الصفر؛ كسور المقياس $\sqrt{\text{mean}(x^2) + \epsilon}$ تضيف ϵ بالضبط لأنّ المشتقق عند 0 يسبب عدم استقرار عددي — جسر مباشر إلى الفصل السابق.

مثال (13-2.7).

- **المعطيات:** $f(x) = \dfrac{1}{x}$ عند $a = 0$.
- **المطلوب:** أثبت عدم وجود النهاية اليمنى (انفجار).
- **الحل:**

١. خذ $\varepsilon = 1$: مهما كان δ اخترنا $x = \min(\delta/2,\ 10^{-6})$.

٢. حينها $f(x) > 10^6 > 1$ لكل اختيار عملي، والحدّ لا يمكن تحقيقه لأيّ L منته. ■

- **النتيجة:** $\lim_{x \to 0^+} \frac{1}{x} = +\infty$ بالمعنى الموسّع — لا نهاية منتهية.

- **الربط بالذكاء الاصطناعي:** خسارة الانتروبيا المتقاطعة عند احتمال متوقَّع $p \to 0^+$ تنفجر كـ $-\log p \to \infty$؛ ولهذا نستخدم clipping الاحتمالات ($p_{\min} = 10^{-8}$ في keras).

مثال (7.2-14).

- **المعطيات:** $f(x) = \dfrac{|x|}{x}$، $x \neq 0$.
- **المطلوب:** النهايات الأحادية عند 0.
- **الحل:**

١. $x \to 0^+ : f = 1$. ٢. $x \to 0^- : f = -1$.

٢. مختلفتان $\Longrightarrow$ لا نهاية. ■

- **النتيجة:** قفزة من -1 إلى $+1$.
- **الربط بالذكاء الاصطناعي:** هذه قفزة دالّة الإشارة مغلفة؛ توضّح لماذا لا يصلح الاتصال وحده لضمان «سلاسة» مسار التعلم — نحتاج تمييز الاتصال عن قابلية الاشتقاق (قسم 4.7).

مثال (7.2-15).

- **المعطيات:** $f(x) = e^x$ عند $a = 0$.
- **المطلوب:** برهن $\lim_{x\to 0} e^x = 1$ باستخدام تعريف النهاية.
- **الحل:**

١. $|e^x - 1| < \varepsilon \iff -\ln(1+\varepsilon) < x < \ln(1+\varepsilon)$ (لـ $\varepsilon > 0$).

٢. نختار $\delta = \ln(1 + \varepsilon/2)$، وهو موجب دائماً.

٣. حينها $|x| < \delta \Rightarrow |e^x - 1| < \varepsilon/2 < \varepsilon$. ■

- **النتيجة:** النهاية $1 =$ بـ $\delta = \ln(1 + \varepsilon/2)$.
- **الربط بالذكاء الاصطناعي:** دوالّ sigmoid و softmax كلّها تركيبات من e^x، استمرارية e^x هي الذي يضمن أنّ «تغيّراً صغيراً في logits يعطي تغيّراً صغيراً في الاحتمالات» — وهو مبدأ استقرار الخرج الذي نعتمده في التدريب.

النظرية

dir="ltr"> <div
then: (finite), $\lim_{x\to a} g(x) = M$ and $\lim_{x\to a} f(x) = L$ If **Laws). (Limit 1.3.7 Theorem**

(2.7)

$$\lim(f \pm g) = L \pm M, \quad \lim(fg) = LM, \quad \lim \frac{f}{g} = \frac{L}{M}\ (M \neq 0), \quad \lim \sqrt{f} = \sqrt{L}\ (L \geq 0)$$

حالات عدم التعيين السبع

الصيغة	النوع	الأداة المفضّلة
$\frac{0}{0}$	كثيرات/جذور/لوغاريتمات	التحليل أو لوبيتال (فصل لاحق) أو تطوير تايلور
$\frac{\infty}{\infty}$	كسور أنموذجية	القسمة على أعلى قوة، تايلور
$0 \cdot \infty$	نواتج متعارضة	تحويلها إلى $\frac{0}{0}$ أو $\frac{\infty}{\infty}$
$\infty - \infty$	فروق متلاصقة	الدمج والتحليل أو المضاعفة بالمرافق
1^∞	أسّية مركّبة	الحدّ e عبر $\exp(\ln(\cdot))$
0^0	الأسّية عند الحدود	نفس تقنية اللوغاريتم
∞^0	أسّية مقلوبة	نفس تقنية اللوغاريتم

مثال تفسيري للحالة 1^∞

$$\lim_{n\to\infty}\left(1+\frac{1}{n}\right)^{n} = e \tag{3.7}$$

برهان موجز.

خذ اللوغاريتم: $\ln = n\ln(1+\frac{1}{n})$. بما أنّ $\ln(1+t) = t + O(t^2)$ فإنّ الحدّ $= n\cdot(\frac{1}{n} + O(\frac{1}{n^2}))$ $= 1 + O(\frac{1}{n}) \to 1$، فالنهاية $= e^1 = e$. ■

- **الربط بالذكاء الاصطناعي:** هذه الحدّية هي أصل «توزيع بواسون كحدّ ذي الحدين»، الذي يُستخدم في نمذجة عدد الأحداث النادرة في التسريّب dropout) بالبواسون) وفي لاسو (الانحدار اللوجستي كنموذج حدّي).

أخطاء شائعة في قوانين النهايات

الخطأ	لماذا خطأ	التصحيح
$\lim(f+g) = \lim f + \lim g$ دائماً	يتطلّب وجود النهايتين (منتهيتين)	تحقّق من الوجود أولاً؛ وإلا استخدم الجبر
«كلّ $\frac{0}{0}$ صفر»	غير معرّفة قبل التبسيط	حلّل أو لوبتال أو تايلور
$\lim(1+1/n)^n = 1$	«الأساس $1 \to$ فالنتيجة 1» خطأ لأنّ الأس $\to \infty$	حالات 1^∞ تحتاج اللوغاريتم
قسمة البسط والمقام على n في $\frac{\infty}{\infty}$ بإهمال الدرجات الأدنى	قد تعطي نتيجة خاطئة في غير المتسلسلات	قسّم على أعلى قوة فعّالة

أمثلة محلولة على قوانين النهايات (15 مثالاً)

مثال (3.7-1).

- **المعطيات:** $\lim_{x\to 2}\dfrac{x^2-4}{x-2}$.
- **المطلوب:** احسب النهاية.
- **الحل:**

١. التعويض يعطي $\frac{0}{0}$.

٢. التحليل: $\frac{(x-2)(x+2)}{x-2} = x+2$ (مسموح لأنّ $x \neq 2$).

٣. النهاية $= 4$. ■

- **النتيجة:** 4.
- **الربط بالذكاء الاصطناعي:** هذا «الميل القاطع المتحول لميل مماسي» — جوهر تعريف المشتقّ في الفصل القادم.

مثال (7.3-2).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{3x^2+5x-1}{6x^2-2x+7}$.
- **المطلوب:** النهاية.
- **الحل:**

١. قسمة على x^2: $\frac{3+5/x-1/x^2}{6-2/x+7/x^2}$.

٢. كل حدّ فيه $1/x \to 0$.

٣. النهاية $= 3/6 = \frac{1}{2}$. ■

- **النتيجة:** $\frac{1}{2}$ — الدرجتان متساويتان فنأخذ نسبة المعاملين القياديين.
- **الربط بالذكاء الاصطناعي:** نسبة المعاملات القيادية تحكم «تضخّم» الخسارة مع الدُفعة الكبيرة (scaling laws): سلوك الذيل يحدّه الحدّ القيادي.

مثال (7.3-3).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{2x^2+x}{x^3-1}$.
- **المطلوب:** النهاية.
- **الحل:**

١. المقام أعلى درجة $\Longrightarrow$ القسمة على x^3: $\frac{2/x+1/x^2}{1-1/x^3}$.

٢. البسط $0 \to$ والمقام $1 \to$.

٣. النهاية $= 0$. ■

- **النتيجة:** 0 — المقام «يهزم» البسط.
- **الربط بالذكاء الاصطناعي:** تلاشي التدرّج في دوالّ التشبع هو نفس النمط: البسط شبه ثابت والمقام ينمو.

مثال (7.3-4).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{\sqrt{x^2+3x}}{x}$، $x \to +\infty$.
- **المطلوب:** النهاية.
- **الحل:**

١. $\sqrt{x^2+3x} = x\sqrt{1+3/x}$ (لأنّ $x>0$).

٢. النهاية $= \sqrt{1+0} = 1$. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** مسافة Norm (الفصل 5): $\|v+\delta\|_2/\|v\|_2 \to 1$ عند التشويش الصغير — أساس براهين الاستقرار للضوضاء اللاإرادية.

مثال (٧.٣-5).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{\sqrt{x^2+3x}}{x}$، $x \to -\infty$.
- **المطلوب:** النهاية على الفرع السالب.
- **الحل:**

١. الآن $x<0$ فحين الخروج من الجذر: $\sqrt{x^2+3x} = |x|\sqrt{1+3/x} = -x\sqrt{1+3/x}$.

٢. النسبة $= -\sqrt{1+3/x} \to -1$.

٣. النهاية $= -1$. ■

- **النتيجة:** -1 — تغيّر إشارة بسبب $|x|$.
- **الربط بالذكاء الاصطناعي:** تذكير: «استخراج x من جذر تربيعي» يفرض $|x|$؛ خطأ شائع في الشيفرة عند التعامل مع تدرّجات سالبة.

مثال (٧.٣-6).

- **المعطيات:** $\lim_{x\to 0} \dfrac{\sqrt{x+9}-3}{x}$.
- **المطلوب:** النهاية $\left(\frac{0}{0}\right)$.
- **الحل:**

١. المضاعفة بالمرافق: $\frac{1}{\sqrt{x+9}+3} = \frac{(x+9)-9}{x(\sqrt{x+9}+3)}$.

٢. التعويض: $\frac{1}{6}$. ■

- **النتيجة:** $\frac{1}{6}$.
- **الربط بالذكاء الاصطناعي:** المرافق هو «الاختزال الشرطي» الذي نطبّقه لتفادي الإلغاء العددي الكارثي (فصل 6): $\sqrt{x+9}-3$ يُحسب في العدّة كـ 0؛ الشكل المُعاد كتابته يُحسب بدقّة.

مثال (7-3.7).

- **المعطيات:** $\lim_{x\to\infty}\left(\sqrt{x^2+x}-x\right)$.
- **المطلوب:** نهاية من نوع $\infty-\infty$.
- **الحل:**

١. المضاعفة بالمرافق: $\frac{x}{\sqrt{x^2+x}+x}$.

٢. قسمة على x: $\frac{1}{\sqrt{1+1/x}+1}\to\frac{1}{2}$.

٣. النهاية $=\frac{1}{2}$. ■

- **النتيجة:** $\frac{1}{2}$.

- **الربط بالذكاء الاصطناعي:** فرق أنموذجي بين «الخسارة الظاهرية» ومكوّن تنظيم: مصطلحات كبيرة متقاربة تُلغي بعضها وتبقى صيغة النصف — لا تُحسب مباشرة في fp16.

مثال (8-3.7).

- **المعطيات:** $\lim_{x\to 0^+} x\ln x$.
- **المطلوب:** نهاية من نوع $0\cdot\infty$.
- **الحل:**

١. اكتب $x\ln x=\frac{\ln x}{1/x}$ (نوع $\frac{\infty}{\infty}$).

٢. بلوبتال (أو المعرفة بأنّ $\ln$ يهزم القوى): $\frac{1/x}{-1/x^2}=-x\to 0$.

٣. النهاية $=0$. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** $p\log p\to 0$ عند $p\to 0^+$ يضمن أنّ الإنتروبيا محدودة على المدخل المتطرف — أساس برهان $H\le\log n$ القادم في فصل الإنتروبيا.

مثال (9-3.7).

- **المعطيات:** $\lim_{x\to\infty}\left(1+\frac{2}{x}\right)^{3x}$.
- **المطلوب:** نهاية من نوع 1^∞.

- **الحل:**

١. خذ اللوغاريتم: $3x\ln(1+2/x) \approx 3x \cdot \frac{2}{x} = 6$.

٢. النهاية $= e^6$. ■

- **النتيجة:** $e^6 \approx 403.43$.

- **الربط بالذكاء الاصطناعي:** «نموّ مركّب» بهذا الشكل يصف تضاعف حجم بيانات التدريب والقدرة في قوانين التوسّع :(Chinchilla) لوغاريتم الحدّ خطّي في المعاملات.

مثال (7.3-10).

- **المعطيات:** $\lim_{x\to 0}(1+3x)^{1/x}$.

- **المطلوب:** النهاية.

- **الحل:**

١. اللوغاريتم: $\frac{\ln(1+3x)}{x} \to 3$ (لأنّ $\ln(1+t) \approx t$).

٢. النهاية $= e^3$. ■

- **النتيجة:** $e^3 \approx 20.09$.

- **الربط بالذكاء الاصطناعي:** «التضاعف الأُسّي بمعدّل لحظي» يصف تراكم الفائدة في regularization من نوع $e^{\lambda x}$؛ ولهذا نستخدم log-space في softmax.

مثال (7.3-11).

- **المعطيات:** $\lim_{x\to 0^+} x^x$.

- **المطلوب:** نهاية من نوع 0^0.

- **الحل:**

١. اللوغاريتم: $x\ln x \to 0$ (مثال 7.3-8).

٢. النهاية $= e^0 = 1$. ■

- **النتيجة:** 1.

- **الربط بالذكاء الاصطناعي:** توزيع «خريطة الحرارة الناعمة» عند الحرارة المرتفعة (temperature $\to \infty$) يقارب التوزيع المنتظم؛ هذه النهاية تظهر في التراجع $0^0 = 1$ المقبول في تعريفات كثيرات الحدود المولّدة.

مثال (7.3-12).

- **المعطيات:** $\lim_{x\to 0} \dfrac{\sin(5x)}{\sin(2x)}$.
- **المطلوب:** النهاية.
- **الحل:**

١. اكتب: $\frac{5}{2} \cdot \frac{2x}{\sin 2x} \cdot \frac{\sin 5x}{5x}$.

٢. كل قوس $\to 1$.

٣. النهاية $= \frac{5}{2}$. ■

- **النتيجة:** $\frac{5}{2}$.

- **الربط بالذكاء الاصطناعي:** «العمود الفقري» $\sin(kx)/(kx) \to 1$ يقابل «التطبيع بالمعدّل» في positional encoding الجيبي؛ المعامل النسبي هو المتبقّي.

مثال (7.3-13).

- **المعطيات:** $\lim_{x\to\infty} \dfrac{x^2 \sin(1/x)}{x}$.
- **المطلوب:** النهاية.
- **الحل:**

١. اكتب: $x \cdot \dfrac{\sin(1/x)}{1/x}$.

٢. القوس $1 \to$ والمقدار الخارجي $\to \infty$.

٣. النهاية $= \infty$ (انبثاق). ■

- **النتيجة:** $+\infty$.

- **الربط بالذكاء الاصطناعي:** تحذير أنّ «خطأً صغيراً مضروباً بعامل كبير» قد ينفجر؛ يجسّد خطر إعادة القياس بعد الضرب بعوامل كبيرة في fp16.

مثال (7.3-14).

- **المعطيات:** $\lim_{x\to 1} \dfrac{\ln x}{x-1}$.
- **المطلوب:** النهاية $\left(\frac{0}{0}\right)$.

- **الحل:**

١. ضع $t = x - 1$: $\frac{\ln(1+t)}{t} \to 1$ (الحدّ المرجعي).

٢. النهاية $= 1$. ■

- **النتيجة:** 1.

- **الربط بالذكاء الاصطناعي:** هذا الحدّ هو «مشتقّ ln عند 1»، ويظهر في divergence: KL $(p \| q)$ — التقريب الخطّي $\ln(p/q) \approx (p-q)/q$ في تحليل الاستقرار للتوزيعات.

مثال (15-3.7).

- **المعطيات:** $\lim_{n\to\infty} \left(\frac{n}{n+1}\right)^n$.

- **المطلوب:** النهاية (1^∞).

- **الحل:**

١. اللوغاريتم: $n \ln \frac{n}{n+1} = n \ln\left(1 - \frac{1}{n+1}\right) \approx n \cdot \left(-\frac{1}{n}\right) = -1$.

٢. النهاية $= e^{-1}$. ■

- **النتيجة:** $e^{-1} \approx 0.368$.

- **الربط بالذكاء الاصطناعي:** احتمال عدم اختيار عنصر معيّن في dropout المعياري $(1-p)^n \to e^{-pn}$ — أساس تحليل توقّع عدد الوحدات الناجية في dropout.

النظرية

dir="ltr"> <div

ffi: a at continuous is f **point). a at (Continuity 1.4.7 Definition**

$$\lim_{x \to a} f(x) = f(a).$$

agree. two the and defined, is $f(a)$ (finite), exists limit the is, That

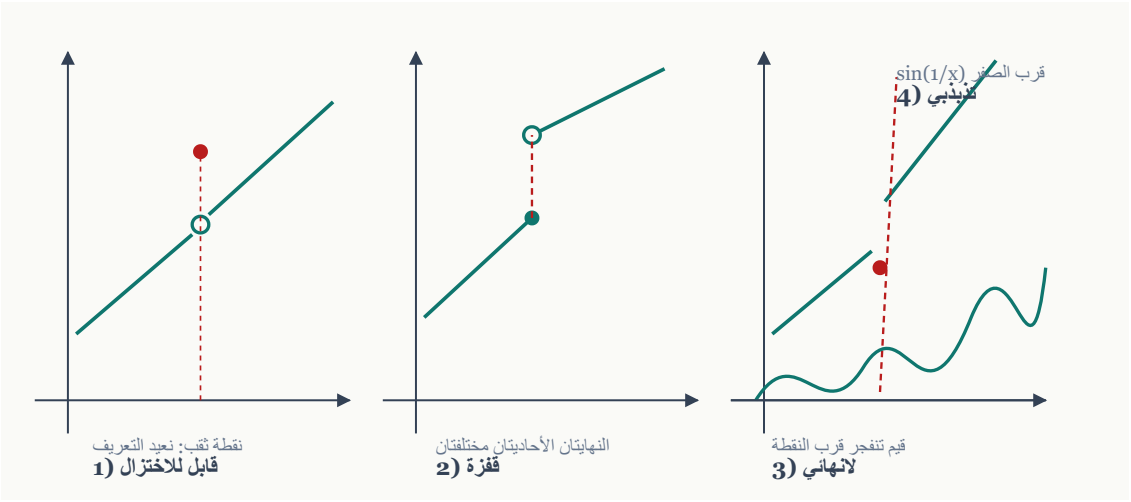
$$f \text{ متصلة عند } a \iff \lim_{x\to a^-} f(x) = \lim_{x\to a^+} f(x) = f(a) \tag{4.7}$$

الاتصال على مجموعة = الاتصال عند كل نقطة فيها.

أنواع الانقطاع الأربعة

النوع	السبب	هل يمكن «إصلاحه» بإعادة تعريف نقطة؟
قابل للاختزال (removable)	النهاية موجودة لكن $f(a)$ غائبة أو مخالفة	نعم
قفزة (jump)	النهايتان الأحاديتان موجودتان ومختلفتان	لا
لانهائي (infinite)	قيم تنفجر قرب النقطة	لا
تذبذبي (oscillatory)	القيم تتذبذب بلا استقرار	لا

<figure> الشكل<figcaption> 2.7: أنواع الانقطاع الأربعة. فقط النوع الأول يُسدّ بإعادة تعريف النقطة؛ الثلاثة الأخرى تعيبات بنيوية في الدالة.</figcaption> </figure>



شكل ٢.٧: *
أنواع الانقطاع الأربعة

أخطاء شائعة في الاتصال

الخطأ	لماذا خطأ	التصحيح
«متصلة يعني قابلة للاشتقاق»	$\lvert x\rvert$ متصلة عند 0 وغير قابلة للاشتقاق	الاتصال أضعف من قابلية الاشتقاق
«المجموع غير متصل بالضرورة»	إن كانت كلتاهما متصلتين فمجموعهما متصل	الانقطاع يظهر في الحاصل أو عند نقاط النقاط الحرجّة فقط
إهمال فحص $f(a)$ نفسها	النهاية قد توجد و $f(a)$ غائبة	المعادلة (4.7) تتطلّب الأطراف الثلاثة
«دالة متصلة تبلغ قيمها كلها»	فقط على المجموعات المغلقة المحدودة (نظرية 2.5.7)	انتبه للمجال

أمثلة محلولة على الاتصال (15 مثالاً)

مثال (4.7-1).

- **المعطيات:** $f(x) = x^2 + 3$.
- **المطلوب:** أثبت الاتصال عند $x = 2$ بتعريف ϵ–δ.
- **الحل:**

١. $f(2) = 7$.

٢. $|f(x) - 7| = |x^2 - 4| = |x - 2||x + 2|$؛ نقيد $|x - 2| < 1 \Rightarrow |x + 2| < 7$.

٣. اختر $\delta = \min(1, \varepsilon/7) \Longrightarrow$ متصلة. ■

- **النتيجة:** متصلة عند 2.

- **الربط بالذكاء الاصطناعي:** كثيرات الحدود متصلة كلّها — دوال الخسارة كثيرات في المعاملات (الانحدار الخطّي) لا تحدث انقطاعات أصلاً؛ المصدر الوحيد للانقطاع هو دوال التنشيط والعمليات اللاخطية.

مثال (7.4-2).

- **المعطيات:** $f(x) = \dfrac{x^2 - 9}{x - 3}$ مع تعريف $f(3)$ غير موجود.
- **المطلوب:** صنّف الانقطاع.
- **الحل:**

١. النهاية $\lim(x + 3) = 6 =$ موجودة.

٢. $f(3)$ غير معرّفة.

٣. انقطاع **قابل للاختزال**، نضع $f(3) = 6$ لنسدّه. ■

- **النتيجة:** انقطاع اختزالي عند 3.

- **الربط بالذكاء الاصطناعي:** الحالة النموذجية «division by zero» عند نقطة واحدة» في دوال التقييم، الحل البرمجي المعتاد (clipping أو epsilon) هو إعادة تعريف نقطة.

مثال (7.4-3).

- **المعطيات:** $f(x) = \begin{cases} x^2 & x \le 1 \\ 2x + 1 & x > 1 \end{cases}$
- **المطلوب:** إيجاد قيم a التي تجعل الدالة متصلة (بشكل عام $f(x) = \begin{cases} x^2 & x \le a \\ 2x + 1 & x > a \end{cases}$).
- **الحل:**

١. الشرط: $a^2 = 2a + 1$.

٢. حلّ: $a^2 - 2a - 1 = 0 \Rightarrow a = 1 \pm \sqrt{2}$.

٣. عند $a = 1$ الأصلي: النهايتان 1 و 3 مختلفتان $\Longrightarrow$ قفزة. ■

- **النتيجة:** عند $a = 1$ انقطاع قفزة، الاتصال يتحقق فقط عند $a = 1 \pm \sqrt{2}$.

- **الربط بالذكاء الاصطناعي:** «مطابقة الطرفين» هو شرط وصل الطبقات في الشبكات المجزّأة (mixture of experts) عندما تتطلب خرجاً متصلاً عند حدود الإسناد.

مثال (7.4-4).

- **المعطيات:** $f(x) = \dfrac{1}{x - 2}$.

- **المطلوب:** صنّف الانقطاع عند 2.
- **الحل:**

١. $\lim_{x\to 2^+} = \infty$، $\lim_{x\to 2^-} = -\infty$.

٢. انقطاع **لانهائي** (خطّ عمودي مقارب). ■

- **النتيجة:** لانهائي عند 2.

- **الربط بالذكاء الاصطناعي:** $-\log p$ عند $p \to 0^+$؛ خسارة cross-entropy لانهائية الانقطاع نظرياً، ولهذا clipping الاحتمالات (10^{-8}) ضرورة عملية لا ترف.

مثال (7.4-5).

- **المعطيات:** $f(x) = \sin\frac{1}{x}$.
- **المطلوب:** صنّف الانقطاع عند 0 (الدالة غير معرّفة هناك).
- **الحل:**

١. في كل جوار للصفر تتذبذب القيم بين -1 و 1 بلا استقرار.

٢. لا نهاية يمنى/يسرى.

٣. انقطاع **تذبذبي**. ■

- **النتيجة:** تذبذبي عند 0.

- **الربط بالذكاء الاصطناعي:** التذبذب عالي التردد في الخسارة عند rates learning كبيرة هو صورة سلوكية لهذا الانقطاع؛ الحل زيادة الدقّة أو تجانس الدُفعات.

مثال (7.4-6).

- **المعطيات:** $f(x) = \text{ReLU}(x) = \max(0, x)$.
- **المطلوب:** افحص الاتصال والقابلية للاشتقاق عند 0.
- **الحل:**

١. $\lim_{x\to 0^-} = 0 = \lim_{x\to 0^+} = f(0) \implies$ متصلة.

٢. الميل الأيسر $0 =$ والأيمن $1 = \implies$ غير قابلة للاشتقاق.

٣. انقطاع **في المشتقّ** لا في الدالة (زاوية). ■

- **النتيجة:** متصلة، غير قابلة للاشتقاق عند 0.

- **الربط بالذكاء الاصطناعي:** القلب النابض للشبكات الحديثة؛ الانتشار العكسي يستخدم subgradient ويعمل عملياً — الاتصال وحده يضمن أنّ الشبكة كلّها متصلة كدالة للمدخلات.

مثال (7-4.7).

- **المعطيات:** $f(x) = \begin{cases} \dfrac{\sin x}{x} & x \neq 0 \\ a & x = 0 \end{cases}$
- **المطلوب:** أوجد a التي تجعل f متصلة عند 0.
- **الحل:**

١. النهاية $= 1$ (مثال 6-2.7).

٢. الشرط $a = 1$. ■

- **النتيجة:** $a = 1$.

- **الربط بالذكاء الاصطناعي:** نمط «ملء الثقب» يظهر في تعريف GELU عند الحدّ: يعتمد التنفيذ القيم الحدّية المسجلة مسبقاً للنقاط الحرجة.

مثال (8-4.7).

- **المعطيات:** $f(x) = \dfrac{1}{1+e^{-x}}$ (sigmoid).
- **المطلوب:** افحص الاتصال على $\mathbb{R}$.
- **الحل:**

١. تركيب e^x المتصلة، مع $x \mapsto -x$، جمع، قسمة بمقام لا يصفري $(1 + e^{-x} \geq 1)$.

٢. تركيب دوال متصلة بلا استثناءات $\Longrightarrow$ متصلة على كل $\mathbb{R}$. ■

- **النتيجة:** متصلة في كل مكان.

- **الربط بالذكاء الاصطناعي:** هذا سبب تفضيل sigmoid في التدرّج مباشرةً بدل العتبة الصلبة: الاتصال الكلي يضمن استمرار التدرّجات على كل المدخلات.

مثال (9-4.7).

- **المعطيات:** $f(x) = \lfloor x \rfloor$ (دالة الجزء الصحيح).
- **المطلوب:** صنّف الانقطاع عند $x = 1$.
- **الحل:**

١. $\lim_{x \to 1^-} = 0$، $\lim_{x \to 1^+} = 1 = f(1)$.

٢. النهايتان مختلفتان بمقدار 1 $\Longrightarrow$ **قفزة.** ■

- **النتيجة:** قفزة عند كل عدد صحيح.

- **الربط بالذكاء الاصطناعي:** المُجدوِل (scheduler) الذي يخفض rate learning خطوة كل 10 حقب له نفس السلوك القفزي؛ الجدولة الكونية (cosine) تحوّله لدالة متصلة.

مثال (7.4-10).

- **المعطيات:** $f(x) = \dfrac{x \sin x}{x^2 + 1}$.

- **المطلوب:** أثبت الاتصال على $\mathbb{R}$.

- **الحل:**

١. $\sin x$ متصلة، x متصلة، حاصل ضرب متصل، المقام > 0 دائماً فالحاصل متصل.

٢. بلا نقاط استثناء $\Longrightarrow$ متصلة كلّياً. ■

- **النتيجة:** متصلة على $\mathbb{R}$.

- **الربط بالذكاء الاصطناعي:** دالة «سقف ناعم» تُستخدم في تقدير الاهتمام المحايد؛ استمراريتها المضمونة بنيوياً تجنّبنا فحص نقاط حرجة.

مثال (7.4-11).

- **المعطيات:** $f(x) = \begin{cases} e^{-1/x^2} & x \neq 0 \\ 0 & x = 0 \end{cases}$

- **المطلوب:** افحص الاتصال عند 0.

- **الحل:**

١. النهاية $0 =$ (مثال 7.2-7).

٢. $f(0) = 0 \Longrightarrow$ متصلة (بل سلسة — كل اشتقاقاتها عند 0 صفر). ■

- **النتيجة:** متصلة عند 0 وسلسة.

- **الربط بالذكاء الاصطناعي:** دوالّ «الوادي المسطّح»؛ الاتصال السلس لا يعني سهولة التحسين — شكل الوادي مهمّ لا السلاسة وحدها.

مثال (7.4-12).

- **المعطيات:** $f(x) = |x-1| + |x-3|$.
- **المطلوب:** نقاط عدم قابلية الاشتقاق مع الاتصال.
- **الحل:**

١. مجموع قدر مطلق متصل؛ انقطاعات الدالة: لا شيء.

٢. عند $x = 1$ و $x = 3$ زوايا (ميل أيسر $\neq$ أيمن) $\Longrightarrow$ غير قابلة للاشتقاق هناك فقط.

٣. الاتصال كامل، الاشتقاق ناقص عند نقطتين. ■

- **النتيجة:** متصلة، زاويتان عند 1 و 3.
- **الربط بالذكاء الاصطناعي:** خسارة L1 لهذا الشكل تماماً، نقاط الزاوية هي «ما تجنّبه خسارة «Huber بالتهيد بين L2 و L1.

مثال (7.4-13).

- **المعطيات:** $f(x) = \begin{cases} x \sin \frac{1}{x} & x \neq 0 \\ 0 & x = 0 \end{cases}$
- **المطلوب:** افحص الاتصال عند 0.
- **الحل:**

١. النهاية $= 0$ بالحصر (مثال 7.2-9).

٢. $f(0) = 0 \Longrightarrow$ متصلة. ■

- **النتيجة:** متصلة عند 0 (رغم التذبذب الداخلي).
- **الربط بالذكاء الاصطناعي:** «تذبذب مغلوب بالسِوار» يصف ضجيج SGD: متوسط المسار متصل وسلس بينما المسار الفعلي يتذبذب — أساس متوسط الأوزان (weight averaging / SWA).

مثال (7.4-14).

- **المعطيات:** $f(x) = \dfrac{x^2 \sin(1/x)}{x}$، $x \neq 0$ (أي $f(x) = x \sin \frac{1}{x}$) مركّبة مع $g(x) = f(x) + x$.
- **المطلوب:** هل يمكن لمجموع دالتين متصلتين أن يكون غير متصل؟
- **الحل:**

١. f متصلة (مثال سابق) و x متصلة.

٢. المجموع g متصل — لا يوجد مثال مضاد.

٣. الاتصال مغلوق تحت الضرب في ثابت والجمع والتركيب. ■

- **النتيجة:** لا، الجمع يحافظ على الاتصال.
- **الربط بالذكاء الاصطناعي:** الخسارة الكلية $L = L_{\text{data}} + \lambda L_{\text{reg}}$ متصلة إذا كانت مكوّناتها كذلك — الانقطاع الوحيد ممكن من العمليات اللاخطية العتبية.

مثال (7.4-15).

- **المعطيات:** $f(x) = \begin{cases} \dfrac{e^x - 1}{x} & x \neq 0 \\ a & x = 0 \end{cases}$
- **المطلوب:** قيمة a للاستمرارية، ثم قيمة قريبة من المشتقّ عند 0.
- **الحل:**

١. $e^x = 1 + x + \frac{x^2}{2} + \cdots \implies \frac{e^x - 1}{x} \to 1$.

٢. إذن $a = 1$.

٣. لاحظ أنّ الحدّ نفسه هو e^0 (مشتقّ e^x) — الجسر إلى الفصل القادم. ■

- **النتيجة:** $a = 1$؛ الحدّ يساوي مشتقّ e^x عند الصفر.

- **الربط بالذكاء الاصطناعي:** «استقرار expm1» — المكتبات تستخدم expm1 تحديداً لتجنّب فقدان دقّة هذا الحدّ عند x صغيرة (استمرار مع الفصل 6: الإلغاء الكارثي).

النظريات

dir="ltr"> <div
Theorem Value (Intermediate 1.5.7 Theorem (Bolzano). — If f is continuous on $[a, b]$, $f(a) \cdot f(b) < 0$ and $c \in (a, b)$ with $f(c) = 0$ exists there.

$$f \in C[a,b],\ f(a)f(b) < 0 \implies \exists\, c \in (a,b) : f(c) = 0 \tag{5.7}$$

dir="ltr"> <div
Theorem Value (Extreme 2.5.7 Theorem). A function continuous on a closed bounded interval $[a, b]$ attains a maximum and a minimum.
Theorem Value (Mean 3.5.7 Theorem for mean-value form, integrals for continuous functions). For $f \in C[a, b]$ and any value Y between $f(a)$ and $f(b)$, there exists $c \in (a, b)$ with $f(c) = Y$.

برهان موجز للبولزانو (بالبحث الثنائي)

١. ثبّت فترة $[a_0, b_0] = [a, b]$ فيها تغيّر إشارة.

٢. افحص المنتصف m: إن كان $f(m) = 0$ انتهينا؛ وإلا اختر النصف الذي يغير الإشارة.

٣. تتكوّن متتالية فترات متداخلة بطول يتنصّف، طولها $\to 0 \implies$ تقارب إلى نقطة وحيدة c.

٤. بالاتصال: $f(c) = 0$. ■

هذا البرهان بنّاء: هو حرفياً خوارزمية Bisection.

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
تطبيق البولزانو على فترة مفتوحة	قد لا يوجد جذر داخل (a,b)	استخدم فترة مغلقة وتغيّر إشارة عند طرفيها
«الاتصال غير ضروري»	دالة قافزة قد تغيّر الإشارة بلا جذر	مثال sgn على $[-1,1]$
«EVT ينجح على فترات غير محدودة»	على $[0,\infty)$ $f(x)=x$ لا يبلغ قيمة قصوى	شرط المغلقة+المحدودة أساسي
الظنّ أنّ EVT يعطي «أين» القيمة القصوى	يعطي الوجود فقط	الموقع يحتاج الفصل 8 (نقاط حرجة)

أمثلة محلولة على نظريات القيم الوسطى (15 مثالاً)

مثال (7.5-1).

- **المعطيات:** $f(x)=x^3-2x-5$ على $[2,3]$.
- **المطلوب:** أثبت وجود جذر في $(2,3)$.
- **الحل:**

١. $f(2)=8-4-5=-1<0$.

٢. $f(3)=27-6-5=16>0$.

٣. f متصلة (كثير حدود) والبولزانو يعطي جذر. ■

- **النتيجة:** جذر وحيد في $(2,3)$ (هذا مثال نيوتن الكلاسيكي).

- **الربط بالذكاء الاصطناعي:** إثبات «وجود حل» قبل البحث عنه عددياً — أساس ضمان توقف الخوارزميات الصرفة في مسائل مساواة الأوزان.

مثال (7.5-2).

- **المعطيات:** $f(x)=x-\cos x$.
- **المطلوب:** أثبت جذر في $(0,1)$.
- **الحل:**

١. $f(0)=-1<0$.

٢. $f(1)=1-\cos 1\approx 0.4597>0$.

٣. البولزانو $\Longrightarrow$ جذر. ■

- **النتيجة:** جذر وحيد (لأنّ $f'=1+\sin x>0$ على $[0,1]$).

- **الربط بالذكاء الاصطناعي:** حلّ معادلات «نقطة التوازن» في آليات الانتباه: نثبت الوجود أولاً بالاتصال، ثم نكرّر التخصيص (fixpoint iteration).

مثال (7.5.3).

- **المعطيات:** $f(x) = x^2$ على $[0, 2]$ والقيمة $Y = 3$.
- **المطلوب:** طبّق نظرية القيمة الوسطى (7.5.3).
- **الحل:**

١. $f(0) = 0 < 4 = f(2)$ و $Y = 3$ بينهما.

٢. $c = \sqrt{3} \in (0, 2)$، $f(c) = 3$. ■

- **النتيجة:** $c = \sqrt{3}$.
- **الربط بالذكاء الاصطناعي:** «إدراج قيمة وسيطة» هو جوهر الاستيفاء (interpolation) بين تضمينات (embeddings): بين متجهي كلمتين نجد متجهاً وسيطاً — الاتصال يضمن عدم «الفراغ».

مثال (7.5.4).

- **المعطيات:** $f(x) = \begin{cases} -1 & x \le 0 \\ 1 & x > 0 \end{cases}$ على $[-1, 1]$.
- **المطلوب:** أثبت فشل البولزانو رغم تغيّر الإشارة.
- **الحل:**

١. $f(-1)f(1) = -1 < 0$.

٢. لكن f غير متصلة عند 0 ولا تساوي صفراً هناك.

٣. لا جذر. ■

- **النتيجة:** الفشل يوضّح ضرورة الاتصال.
- **الربط بالذكاء الاصطناعي:** تذكير بأنّ دوالّ العتبة الصلبة (hard threshold) قد تفوّت الحلول الوسيطة؛ الدوالّ الناعمة تُصلح ذلك نظرياً وعملياً.

مثال (7.5.5).

- **المعطيات:** $f(x) = x^4 - 4x^2 + 4$ على $[-3, 3]$.
- **المطلوب:** أوجد القيم القصوى وفوقها نظرية EVT.
- **الحل:**

١. $f = (x^2 - 2)^2 \ge 0$؛ القيمة الصغرى 0 عند $x = \pm\sqrt{2}$.

٢. القيمة العظمى عند الأطراف: $f(\pm 3) = 81 - 36 + 4 = 49$.

٣. EVT يضمن الوجود؛ الحساب أعلاه يطبّقه. ■

- **النتيجة:** صغرى 0 عند $\pm\sqrt{2}$؛ عظمى 49 عند ± 3.
- **الربط بالذكاء الاصطناعي:** تحليل «مدى الخسارة» على كرة قياسية حول الأوزان: EVT يضمن وجود أسوأ حالة داخل الكرة — أساس تحليل SM. (sharpness)

مثال (7.5-6).

- **المعطيات:** $f(x) = \tan x$ على $[0, \pi]$.
- **المطلوب:** لماذا لا يسري EVT؟
- **الحل:**

١. tan غير متصلة على الفترة كاملة (انقطاع لانهائي عند $\pi/2$).

٢. القيم القصوى غير موجودة (تطير إلى $\pm\infty$). ■

- **النتيجة:** انقطاع واحد يهدم EVT.
- **الربط بالذكاء الاصطناعي:** خسارة متباعدة قرب احتمال صفر لهذا السلوك؛ clipping = «إزالة الانقطاع» بالفرض.

مثال (7.5-7).

- **المعطيات:** معادلة $e^x = 3 - x$.
- **المطلوب:** أثبت حلّاً وحيداً في $(0, 1)$.
- **الحل:**

١. $g(x) = e^x + x - 3$: $g(0) = -2 < 0$، $g(1) = e - 2 \approx 0.718 > 0$.

٢. جذر بالبولزانو.

٣. $g' = e^x + 1 > 0 \Longrightarrow$ تقاطع وحيد. ■

- **النتيجة:** حلّ وحيد في $(0, 1)$.
- **الربط بالذكاء الاصطناعي:** حلّ «شروط التوازن» في تحليل استقرار شبكات المتباينات (GAN) يبدأ بهذا النمط: دالة متصلة وتمييز إشارة عند طرفين.

مثال (7.5-8).

- **المعطيات:** $f(x) = \sin x$ على $[0, 2\pi]$.
- **المطلوب:** طبّق 3.5.7 للقيمة $Y = 0$ (غير القيم الطرفية).
- **الحل:**

١. $f(0) = f(2\pi) = 0$؛ نريد نقطة داخلية c بقيمة 0: $c = \pi$.

٢. فعلاً $f(\pi) = 0 \in (0, 2\pi)$. ■

- **النتيجة:** $c = \pi$ يحقّق القيمة الوسيطة.

- **الربط بالذكاء الاصطناعي:** «العبور الصفري» في الإشارات الدورية هو أساس مصادر العدّ (phase reset) في أدوات تحليل التدرّج الزمني — وتكرار ثبات التوقيت.

مثال (5.7-9).

- **المعطيات:** $f(x) = \frac{1}{x}$ على $[-1, 1], x \neq 0$.
- **المطلوب:** فحص EVT.
- **الحل:**

١. f غير متصلة عند 0 (لانهائية).

٢. لا قيمة عظمى ولا صغرى على الفترة. ■

- **النتيجة:** EVT لا يسري.

- **الربط بالذكاء الاصطناعي:** الخسارة المستوية في «عينات متنافرة» تكشف هذا النمط؛ الاستمرارية شرط الجولة الشاملة لأسوأ الحالات.

مثال (5.7-10).

- **المعطيات:** $f(x) = x^2$ على $(0, 1)$ (فترة مفتوحة).
- **المطلوب:** هل يبلغ القيمة العظمى؟
- **الحل:**

١. القيم تقارب 1 لكن لا تبلغه (1 خارج الفترة).

٢. الصغرى 0 أيضاً غير محقّقة (0 خارج الفترة). ■

- **النتيجة:** لا قيمة قصوى على الفترة المفتوحة.

- **الربط بالذكاء الاصطناعي:** «البحث داخل كرة مفتوحة» قد يفشل في بلوغ أفضل حالة؛ كرة مغلقة (قيد صلب) أساس تحليل الشمول العالمي.

مثال (5.7-11).

- **المعطيات:** $f(x) = x + \sin x$ على $[-2, 2]$.
- **المطلوب:** أثبت أنّ f تبلغ قيمة 1 داخل الفترة.
- **الحل:**

١. $f(-2) \approx -2.909 < 1$.

٢. $f(2) \approx 2.909 > 1$.

٣. البولزانو (بصيغة 3.5.7 على $g = f - 1$) $\Longrightarrow$ نقطة تحقق $f = 1$. ■

- **النتيجة:** توجد نقطة c بـ $f(c) = 1$.

- **الربط بالذكاء الاصطناعي:** التحقّق من «معدّل معقول» بين طرفي مدى التدرّج: القيمة الوسيطة موجودة بالاتصال، والبحث الثنائي يصل إليها بسرعة لوغاريتمية.

مثال (5.7-12).

- **المعطيات:** $f(x) = x^3 - x$ على $[-2, 2]$.
- **المطلوب:** القيم القصوى وطبّق EVT.
- **الحل:**

١. $f' = 3x^2 - 1 = 0 \Rightarrow x = \pm 1/\sqrt{3}$.

٢. محليّاً: قيمة صغرى عند $+1/\sqrt{3}$ بقيمة ≈ -0.385، عظمى ≈ 0.385.

٣. عند الأطراف $f(\pm 2) = \pm 6$ $\Longrightarrow$ العظمى 6 عند $x = 2$. ■

- **النتيجة:** عظمى 6 عند الطرف، صغرى -6 عند -2.

- **الربط بالذكاء الاصطناعي:** «القيم القصوى عند الأطراف» تجسّد لماذا نقيد الأوزان (weight clipping) في WGAN: الأطراف المقيّدة تحكم الحدّ الأعلى للخسارة.

مثال (5.7-13).

- **المعطيات:** $f(x) = x^2 \cos x$ على $[0, 10]$.
- **المطلوب:** أثبت وجود قيمة عظمى (بلا حسابها).
- **الحل:**

١. f متصلة على فترة مغلقة محدودة.

٢. EVT $\Longrightarrow$ قيمة عظمى و صغرى محقّقتان. ■

- **النتيجة:** الوجود مضمون.

- **الربط بالذكاء الاصطناعي:** «حلقة الحماية» الأولى: نثبت الوجود نظرياً قبل محاولة الاستمثال عددياً — القيمة موجودة، وينحصر السؤال في إيجادها.

مثال (7.5-14).

- **المعطيات:** $f(x) = \lfloor x \rfloor$ على $[0, 3]$.
- **المطلوب:** هل يسري EVT؟
- **الحل:**

١. f متصلة على $[0, 3)$... لا؛ غير متصلة عند 1 و 2.

٢. مع ذلك توجد قيم قصوى (0 و 2) — لكن EVT **لا يضمنها.**

٣. درس: صحة الشرط ضروري لكنه ليس دائماً «ضرورياً» — شرط كافٍ. ■

- **النتيجة:** EVT شرط كافٍ لا ضروري.

- **الربط بالذكاء الاصطناعي:** لا تخلط بين «يضمن» و«يمنع»؛ دوال غير سلسة قد تعمل عملياً لكن بلا ضمانات نظرية.

مثال (7.5-15).

- **المعطيات:** $f(x) = 2^x - 4x$.
- **المطلوب:** أثبت وجود جذرين أحدهما في $(0, 1)$ والآخر في $(3, 4)$.
- **الحل:**

١. $f(0) = 1 > 0$، $f(1) = -2 < 0$ $\Longrightarrow$ جذر في $(0, 1)$.

٢. $f(3) = 8 - 12 = -4 < 0$، $f(4) = 16 - 16 = 0$ (جذر طرفي!) — لاحظ أنّ 4 جذر بالضبط.

٣. لجذر داخلي: على $(3, 4)$ النهاية عند الطرف الأيمن تعطي إشارة صفر، فالبولزانو قد لا يضمن داخلية. فعلاً $x = 4$ جذر. ■

- **النتيجة:** جذران: أحدهما في $(0, 1)$ وآخر $x = 4$ (طرفي).

- **الربط بالذكاء الاصطناعي:** «الجذر الطرفي» تحذير في تحليل التقارب: قد تتقارب الخوارزمية إلى حدّ القيد (boundary) لا إلى «الحل الداخلي» الذي نتوقّعه — يجب فحص القيود قبل الاحتفال.

النظرية

dir="ltr"> <div
$\forall \varepsilon > 0\ \exists N \in \mathbb{N} :\ n \geq N \Rightarrow$ ffi $a_n \to L$ **convergence). (Sequence 1.6.7 Definition**
.$|a_n - L| < \varepsilon$
$\forall \varepsilon > 0\ \exists N :\ m, n \geq N \Rightarrow |a_m -$ ffi Cauchy is a_n **sequence). (Cauchy 2.6.7 Definition**
.$a_n| < \varepsilon$
Cauchy. is $a_n \iff$ converges a_n :$\mathbb{R}$ In **.1.6.7 Theorem**

$$a_n \to L \iff \forall \varepsilon > 0\ \exists N :\ n \geq N \Rightarrow |a_n - L| < \varepsilon \tag{6.7}$$

$$a_n \text{ كوشي} \iff \forall \varepsilon > 0\ \exists N :\ m, n \geq N \Rightarrow |a_m - a_n| < \varepsilon \tag{7.7}$$

النظرية 2.6.7 (قواعد الجبر على المتتاليات). إذا كانت $a_n \to L$، $b_n \to M$ فإنّ $a_n \pm b_n \to L \pm M$، $a_n b_n \to LM$، $\frac{a_n}{b_n} \to \frac{L}{M}$ $(M \neq 0)$.

نظرية الضغط (Squeeze)

$$b_n \leq a_n \leq c_n, \quad b_n \to L,\ c_n \to L \implies a_n \to L \tag{8.7}$$

أخطاء شائعة في التقارب المتسلسلي

الخطأ	لماذا خطأ	التصحيح
«تقارب يعني وصولاً»	$1/n \to 0$ دون أن يبلغ 0 أيّ حدّ	التقارب اقتراب لا بلوغ
$\lvert a_{n+1} - a_n\rvert \to 0$ يكفي للتقارب	مثال مضاد: $a_n = \ln n$ (الفروق $\to 0$ والحدّية $\to \infty$)	شرط كوشي أقوى
الحدّية المتزايدة المحدودة قد «تتجاوز» الحدّ	لا، إن كانت متزايدة ومحدودة فتقارب إلى L	$a_n \nearrow L$ مع $a_n \leq L$ دائماً
جمع سلاسل لا نهائية كأعداد منتهية	$\sum 1/n$ يتباعد رغم $1/n \to 0$	السلاسل تحتاج اختبار خاص (فصل لاحق)

أمثلة محلولة على التقارب المتسلسلي (15 مثالاً)

مثال (6.7-1).

- **المعطيات:** $a_n = \dfrac{1}{n}$.
- **المطلوب:** برهن $a_n \to 0$ بتعريف (6.7).
- **الحل:**
١. لكل $\varepsilon > 0$ اختر $N = \lceil 1/\varepsilon \rceil$.
٢. $n \geq N \Rightarrow \frac{1}{n} \leq \frac{1}{N} < \varepsilon$. ■
- **النتيجة:** تقارب إلى 0.
- **الربط بالذكاء الاصطناعي:** $1/n$ rate learning (جدولة عكسية) تلبي شروط تقارب Robbins–Monro — أساس إثبات تقارب SGD الأصلي.

مثال (7.6-2).

- **المعطيات:** $a_n = \dfrac{(-1)^n}{n}$.
- **المطلوب:** النهاية بتعريف ϵ–N.
- **الحل:**

١. $|a_n - 0| = 1/n$.

٢. نفس اختيار N كما في المثال السابق. ■

- **النتيجة:** تقارب إلى 0 (رغم التذبذب في الإشارة).

- **الربط بالذكاء الاصطناعي:** ضجيج SGD المتلاشي المضروب بمعدّل متناقص — التذبذب لا يمنع التقارب إذا كان السِوَار يتلاشى.

مثال (7.6-3).

- **المعطيات:** $a_n = \dfrac{n}{n+1}$.
- **المطلوب:** النهاية.
- **الحل:**

١. $a_n = 1 - \frac{1}{n+1}$.

٢. $|a_n - 1| = \frac{1}{n+1} < \frac{1}{n} \to 0$. ■

- **النتيجة:** الحدّ $= 1$.

- **الربط بالذكاء الاصطناعي:** «نسبة النجاح» على عينة تنمو: يتقارب إلى الحدّ الحقيقي 1 من الأسفل — أساس قانون الأعداد الكبيرة في التقييم.

مثال (7.6-4).

- **المعطيات:** $a_n = \ln n$.
- **المطلوب:** هل $|a_{n+1} - a_n| \to 0$ تكفي للتقارب؟
- **الحل:**

١. $|a_{n+1} - a_n| = \ln \frac{n+1}{n} = \ln(1 + \frac{1}{n}) \to 0$.

٢. لكنّ $a_n \to \infty$ — تتباعد. ■

- **النتيجة:** صفر الفروق لا يكفي؛ شرط كوشي أقوى.

- **الربط بالذكاء الاصطناعي:** تذكير بأنّ «تقلّص الخطوة» وحده لا يضمن توقف الخسارة — يجب فحص التقارب الكلي (شرط كوشي على مسار الأوزان).

مثال (7.6-5).

- **المعطيات:** $a_n = \sqrt{n+1} - \sqrt{n}$.
- **المطلوب:** النهاية (بالمضاعفة بالمرافق).
- **الحل:**

١. $a_n = \dfrac{1}{\sqrt{n+1} + \sqrt{n}}$.

٢. بين $\frac{1}{2\sqrt{n+1}}$ و $\frac{1}{2\sqrt{n}}$؛ كلاهما $\to 0$.

٣. بالضغط: النهاية 0. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** «تحسين هامشي متلاشٍ»: إضافة طبقة جديدة تحسّن الخسارة بمقدار ينكمش كـ $O(1/\sqrt{n})$ — قاعدة التخفيض المتناقص في قوانين التوسّع.

مثال (7.6-6).

- **المعطيات:** $a_n = (1 + \frac{1}{n})^n$.
- **المطلوب:** النهاية.
- **الحل:**

١. من (7.3): الحدّ e.

٢. والمتتالية متزايدة ومحدودة بـ e. ■

- **النتيجة:** $a_n \nearrow e$.

- **الربط بالذكاء الاصطناعي:** «نموّ مركّب بخطوات صغيرة» يساوي النموّ الأُسّي — لماذا نفضّل تحديثات صغيرة متكرّرة على خطوات كبيرة نادرة.

مثال (7.6-7).

- **المعطيات:** $a_n = \dfrac{\sin n}{n}$.
- **المطلوب:** النهاية بالضغط.
- **الحل:**

١. $-\frac{1}{n} \le a_n \le \frac{1}{n}$.

٢. الطرفان $\to 0 \implies$ النهاية 0. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** إشارة اهتمام مقسومة على «درجة الحرارة» المتنامية تتلاشى رغم تذبذب البسط — الضغط يجيب دون حساب البسط.

مثال (7.6-8).

- **المعطيات:** $a_n = \frac{n!}{n^n}$.
- **المطلوب:** النهاية.
- **الحل:**

١. $a_n = \frac{1 \cdot 2 \cdots n}{n \cdot n \cdots n} \le \frac{1}{n} \cdot \frac{2}{n} \cdots$؛ في الواقع $0 \le a_n \le \frac{1}{n} \cdot 1^{n-1}$ لأنّ كل عامل ≤ 1 باستثناء الأول؛ بدقّة: $a_n = \prod_{k=1}^{n} \frac{k}{n} \le \frac{1}{n}$.

٢. بالضغط: $0 \to$. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** «نموّ العوامل» يقابل انفجار الاحتمالات المشتركة في البيايز الساذج عند ضرب مئات الاحتمالات الصغيرة — لهذا نستخدم اللوغاريتمات (log-space).

مثال (7.6-9).

- **المعطيات:** $a_0 = 0$ مع $a_{n+1} = \frac{a_n}{2} + 1$.
- **المطلوب:** النهاية (تكرار نقطة ثابتة).
- **الحل:**

١. إذا تقاربت إلى L فإنّ $L = \frac{L}{2} + 1 \Rightarrow L = 2$.

٢. $|a_{n+1} - 2| = \frac{1}{2}|a_n - 2| \Longrightarrow |a_n - 2| = 2^{-n}|a_0 - 2| \to 0$. ■

- **النتيجة:** تقارب خطّي إلى 2 بعامل $\frac{1}{2}$.

- **الربط بالذكاء الاصطناعي:** هذا «التكرار الانكماشي» نفسه في خوارزميات iteration value للتعلم المعزّز: انكماش $\gamma < 1$ يضمن التقارب الهندسي.

مثال (7.6-10).

- **المعطيات:** $a_n = (-1)^n$.
- **المطلوب:** هل هي كوشي؟
- **الحل:**

١. خذ $\varepsilon = 1$: لأيّ N اختَر $n = N$ (زوجي) و $m = N + 1$ (فردي).

٢. $|a_m - a_n| = 2 > 1 \Longrightarrow$ ليست كوشي. ■

- **النتيجة:** تتباعد (تذبذب ثابت).

- **الربط بالذكاء الاصطناعي:** «الخسارة تقفز بين حوضين» — تقارب المسار يتطلّب تخميداً (momentum) يكسر التذبذب، لا مجرد انتظار.

مثال (7.6-11).

- **المعطيات:** $a_n = \frac{1}{\ln(n+1)}$.
- **المطلوب:** النهاية.
- **الحل:**

١. المقام $\infty \to$ ببطء ($\ln$ لأنّ يهزم بلا شيء... في الواقع $\ln(n+1) \to \infty$).

٢. الحدّية $0 \to \frac{1}{\ln(n+1)} > 0$. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** معدّلات تعلّم لوغاريتمية البطء تنمو نطاقها ببطء؛ التبريد المقابل بطيء جداً — الشهرة: «لوغاريتم يهزم القوة الخطية».

مثال (7.6-12).

- **المعطيات:** $a_n = \frac{n^2}{2^n}$.
- **المطلوب:** النهاية (الأسّي يهزم كثير الحدود).
- **الحل:**

١. $a_{n+1}/a_n = \frac{(n+1)^2}{2n^2} \to \frac{1}{2} < 1$.

٢. من حدّ معيّن البسط يتناقص هندسياً $\Longrightarrow a_n \to 0$. ■

- **النتيجة:** 0.

- **الربط بالذكاء الاصطناعي:** «الأسّي يهزم كثير الحدود» يبرّر تفضيل الدوالّ الأسّية (softmax) في بناء التوزيعات: ذيلها يخمد أي نموّ كثيري.

مثال (7.6-13).

- **المعطيات:** $a_n = \frac{n!}{n^n e^{-n}\sqrt{2\pi n}}$ (نسبة ستيرلنغ).
- **المطلوب:** النهاية.
- **الحل:**

١. صيغة ستيرلنغ: $n! \approx \sqrt{2\pi n}\,(n/e)^n\, e^{\theta_n/12n}$.

٢. النسبة $\to e^0 = 1$. ■

- **النتيجة:** 1 — التقارب إلى ستيرلنغ.

- **الربط بالذكاء الاصطناعي:** ستيرلنغ يقدّر لوغاريتمات التوافيق في انتروبيا التصنيفات الكبيرة (مفردات ضخمة) — تقريب أساسي في فصل الإنتروبيا.

مثال (7.6-14).

- **المعطيات:** $a_0 = 1$، $a_{n+1} = \sqrt{2 + a_n}$.
- **المطلوب:** النهاية.
- **الحل:**

١. حدّية: إنّ $a_n \leq 2$ (بالاستقراء) والمتتالية متزايدة.

٢. متزايدة ومحدودة $\Longrightarrow$ تقارب (نظرية 3.6.7: الحدّية المتزايدة المحدودة تقارب).

٣. الحدّ $L = \sqrt{2 + L} \Rightarrow L^2 - L - 2 = 0 \Rightarrow L = 2$. ■

- **النتيجة:** تقارب إلى 2.

- **الربط بالذكاء الاصطناعي:** نفس نمط «التكرار الانكماشي نحو نقطة ثابتة» في حلّ Bellman في التعلم المعزّز — انكماش يضمن التفرد والتقارب.

مثال (7.6-15).

- **المعطيات:** $a_n = \sum_{k=1}^{n} \frac{1}{k}$ (المتسلسلة التوافقية).
- **المطلوب:** هل هي كوشي؟
- **الحل:**

١. $S_{2n} - S_n = \sum_{k=n+1}^{2n} \frac{1}{k} \geq n \cdot \frac{1}{2n} = \frac{1}{2}$.

٢. لكل N اختيار $n = N$ يعطي فرقاً $\geq \frac{1}{2} \Longrightarrow$ ليست كوشي (اختر $\varepsilon = \frac{1}{3}$). ■

- **النتيجة:** التباعد — رغم $1/k \to 0$.

- **الربط بالذكاء الاصطناعي:** تحذير شامل: «حدود صغيرة لا تعني مجموعاً منتهياً» — مسألة جمع التدرّجات الصغيرة عبر حقب لا نهائية في التحليلات النظرية؛ دائماً قارن بمقياس كوشي.

النظرية

dir="ltr"> <div

Pointwise 1.7.7 Definition (ffi D on pointwise $f_n \to f$ convergence). $\forall x \in D$: $f_n(x) \to f(x)$.

Unfiorm 2.7.7 Definition (ffi D on unfiormly $f_n \to f$ convergence).

$$\forall \varepsilon > 0 \; \exists N : \; n \geq N \Rightarrow \sup_{x \in D} |f_n(x) - f(x)| < \varepsilon.$$

$$f_n \rightrightarrows f \iff \varepsilon_n := \sup_{x \in D} |f_n(x) - f(x)| \to 0 \tag{9.7}$$

النظرية 1.7.7 (حفظ الاتصال). إذا كانت كل f_n متصلة على D و $f_n \rightrightarrows f$ فإنّ f متصلة على D.

النظرية 2.7.7 (تبديل النهاية والتكامل). على فترة محدودة $[a,b]$: التقارب الموحّد يسمح بـ

$$\lim_{n\to\infty} \int_a^b f_n = \int_a^b \lim_{n\to\infty} f_n. \tag{10.7}$$

المثال المضاد الشهير

$$f_n(x) = x^n \text{ على } [0,1]: \quad f_n(x) \to \begin{cases} 0 & x < 1 \\ 1 & x = 1 \end{cases} \tag{11.7}$$

النهاية f **غير متصلة** رغم أنّ كل f_n متصلة — لأنّ التقارب نقطيّ وليس موحّداً: $\sup_{[0,1]} |f_n - f| = 1$ لكل n.

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«النقطي كافٍ لتبديل النهاية مع التكامل»	المثال (11.7) يهدمه	موحّد (أو شروط مسيطرة: التقارب المسيطر)
«sup صعب، سأفحص نقطة واحدة»	النقطي يقيس نقاطاً منفردة	الموحّد يقيس «أسوأ نقطة» دفعة واحدة
«المشتقّ يتقارب إذا تقاربت الدوالّ»	يحتاج تقارب المشتقّات نفسها + نقطة	شرط إضافي
الظنّ أنّ التوحيد ينجح على مجال غير محدود تلقائياً	$e^{-x/n}$ على $[0,\infty)$: $\sup = 1$ لا يتلاشى	افحص sup على المجال كله

أمثلة محلولة على التقارب الوظيفي (15 مثالاً)

مثال (7.7-1).

- **المعطيات:** $f_n(x) = x/n$ على $[0,10]$.
- **المطلوب:** أثبت التقارب الموحّد إلى 0.
- **الحل:**

١. $\sup_{[0,10]} |x/n| = 10/n \to 0$.

٢. بالتعريف (9.7) $\Rightarrow$ موحّد. ■

- **النتيجة:** موحّد إلى 0.
- **الربط بالذكاء الاصطناعي:** «تقارب أسوأ نقطة» هو مقياس تحمّل الشبكة عبر المدخلات؛ إثبات موحّد يعطي ضمانة لكل المدخلات دفعة واحدة — أهمّ بكثير من ضمانات النقطة.

مثال (7.7-2).

- **المعطيات:** $f_n(x) = x^n$ على $[0,1]$.
- **المطلوب:** الفحص النقطي والموحّد.
- **الحل:**

١. نقطياً: f كما في (7.11) — غير متصلة.

٢. $\sup|f_n - f| = 1$ لكل n (قرب $x \to 1^-$).

٣. لا تقارب موحّد. ■

- **النتيجة:** نقطي فقط.

• **الربط بالذكاء الاصطناعي:** هذا نمط «الجبل يزحف نحو الحافة»: تقارب جيد في الداخل وتفشّل عند الحافة — نظير تدهور أداء شبكة عند المدخلات الشاذة (out-of-distribution).

مثال (7.7-3).

- **المعطيات:** $f_n(x) = \frac{\sin(nx)}{n}$ على $\mathbb{R}$.
- **المطلوب:** الموحّد؟ وهل تُحفظ قابلية الاشتقاق للنهاية؟
- **الحل:**

١. $\sup|f_n| \le \frac{1}{n} \to 0 \implies$ موحّد إلى 0.

٢. لكنّ $f_n' = \cos(nx)$ لا تقارب نقطياً إلى 0 (تتذبذب).

٣. النهاية ثابتة قابلة للاشتقاق، لكن «تقارب الدوال لا يورّث تقارب المشتقّات». ■

- **النتيجة:** موحّد إلى 0؛ المشتقّات لا تتقارب.

• **الربط بالذكاء الاصطناعي:** الخسارة قد تتقارب بمظهر جيد بينما التدرّجات تتذبذب بعنف — مراقبة التدرّج ضرورية لا الخسارة وحدها.

مثال (7.7-4).

- **المعطيات:** $f_n(x) = \frac{x}{1+n^2x^2}$ على $\mathbb{R}$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: عند $x \neq 0$ المقام يهزم $\Longrightarrow$ 0؛ عند $x = 0$ القيمة 0. النهاية $f \equiv 0$ متصلة.

٢. أقصى $|f_n|$ عند $x = \frac{1}{n}$: القيمة $\frac{1}{2n} \to 0$.

٣. موحّد. ■

- **النتيجة:** موحّد إلى 0.

- **الربط بالذكاء الاصطناعي:** «ذروة متنقلة متناقصة» — قمم الاهتمام في الشبكات قد تتحرك لكنّ ارتفاعها يتلاشى؛ المقياس الموحّد يلتقط ذلك.

مثال (7.7-5).

- **المعطيات:** $f_n(x) = \frac{nx}{1+n^2x^2}$ على $\mathbb{R}$.
- **المطلوب:** قارن بالمثال السابق.
- **الحل:**

١. نقطياً: $0 \to$ لكل x (نفس الحساب).

٢. لكنّ الذروة عند $x = \frac{1}{n}$ بقيمة $\frac{1}{2}$ — لا تتلاشى.

٣. $\sup = \frac{1}{2} \Longrightarrow$ لا موحّد. ■

- **النتيجة:** نقطي فقط.

- **الربط بالذكاء الاصطناعي:** مضاد حاسم: تضخيم البسط (عمق أكبر) يخلق «شوكة» متحركة لا تتلاشى رغم تقارب كل نقطة — استقرار تدريجي زائف.

مثال (7.7-6).

- **المعطيات:** $f_n(x) = x^n(1-x)$ على $[0,1]$.
- **المطلوب:** الموحّد؟
- **الحل:**

١. نقطياً $0 \to$ (بما فيها عند 1).

٢. الذروة عند $x = \frac{n}{n+1}$ بقيمة $\frac{1}{n+1}\left(\frac{n}{n+1}\right)^n \approx \frac{e^{-1}}{n} \to 0$.

٣. موحّد. ■

- **النتيجة:** موحّد إلى 0.

- **الربط بالذكاء الاصطناعي:** «عامل التخميد» $(1-x)$ قرب الحافة أنقذ التوحيد — إمكانية إصلاح التقارب عند الحواف بعامل يُطفئها (قناع حافة).

مثال (7.7-7).

- **المعطيات:** $f_n(x) = \frac{1}{1+e^{-nx}}$ (sigmoid حادّة) على $\mathbb{R}$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: $x > 0 \to 1$، $x < 0 \to 0$، $x = 0 \to \frac{1}{2}$.

٢. النهاية دالة عتبة غير متصلة $\Longrightarrow$ لا موحّد (بحفظ الاتصال 1.7.7).

٣. $\sup = \frac{1}{2}$ عند $x = 0$. ■

- **النتيجة:** نقطي فقط؛ الحدّ هو الخطوة الصلبة.

- **الربط بالذكاء الاصطناعي:** «حدّ درجة الحرارة»: softmax بدرجة حرارة $0 \to$ يصير argmax صلباً؛ الاتصال يُفقد عند الحدّ — خطر في التقطير (distillation) عند درجات حرارة صغيرة جداً.

مثال (8.7-7).

- **المعطيات:** $f_n(x) = \min(1,\, n\,\mathrm{ReLU}(x))$ على $\mathbb{R}$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: $x > 0 \to 1$، $x \le 0 \to 0$ (خطوة صلبة).

٢. $\sup = \frac{1}{2}$ عند $x = \frac{1}{2n}$.

٣. لا موحّد. ■

- **النتيجة:** نقطي فقط.

- **الربط بالذكاء الاصطناعي:** Straight-Through Estimator» يقارب المؤشر الصلب بدوال ناعمة متزايدة الحدة؛ هذا المثال يوضّح لماذا يجب رفع الحدة تدريجياً (annealing) لا فجأة.

مثال (9.7-7).

- **المعطيات:** $f_n(x) = \sum_{k=1}^{n} \frac{x^k}{k!}$ على $[-R, R]$ لأيّ R منتهٍ.
- **المطلوب:** الموحّد إلى e^x؟
- **الحل:**

١. الباقي $|e^x - f_n(x)| \le \sum_{k>n} \frac{R^k}{k!} \to 0$ (مستقل عن x).

٢. موحّد على $[-R, R]$ لكل R. ■

- **النتيجة:** موحّد محلياً (locally unfiorm).

- **الربط بالذكاء الاصطناعي:** هذا «التقارب المحلي الموحّد» يبرّر تبديل النهايات في اشتقاق سلاسل دوال التنشيط، ولهذا تعمل التنفيذات المقطّعة (truncated series) بشكل موثوق على نطاق محدود.

مثال (7.7-10).

- **المعطيات:** $f_n(x) = e^{-nx}$ على $[0, 1]$.

- **المطلوب:** النقطي والموحّد.

- **الحل:**

١. نقطياً: $x > 0 \to 0$، $x = 0 \to 1$. النهاية متقطعة.

٢. $\sup = 1 \implies$ لا موحّد. ■

- **النتيجة:** نقطي فقط.

- **الربط بالذكاء الاصطناعي:** «تلاشي ذاكرة» في RNN: e^{-nx} يفقد كل المحتوى في كل نقطة عدا نقطة الصفر — التذكّر الطويل يحتاج آليات بوّابية (LSTM) لا الأسّيات وحدها.

مثال (7.7-11).

- **المعطيات:** $f_n(x) = \frac{x^n}{n}$ على $[0, 1]$.

- **المطلوب:** الموحّد؟

- **الحل:**

١. $\sup |f_n| \le \frac{1}{n} \to 0$.

٢. موحّد إلى 0. ■

- **النتيجة:** موحّد.

- **الربط بالذكاء الاصطناعي:** قسماً بـ n (الاستقرار الزمني) «يهدّئ» جبل x^n — تسوية النواتج بطول المسار تحوّل التقارب النقطي إلى موحّد.

مثال (7.7-12).

- **المعطيات:** $f_n(x) = \sin\left(x + \frac{1}{n}\right)$ على $\mathbb{R}$.
- **المطلوب:** الموحّد إلى $\sin x$؟
- **الحل:**

١. $|f_n - \sin x| \le \frac{1}{n}$ (بالتقريب: $|\sin u - \sin v| \le |u - v|$).

٢. $\sup \le \frac{1}{n} \to 0 \implies$ موحّد. ■

- **النتيجة:** موحّد.

- **الربط بالذكاء الاصطناعي:** إزاحة طور صغيرة موحّدة التأثير — «الإزاحة الصغيرة على كل الرؤوس» في الانتباه لا تخرّب الاتصال، مضاد للفكر الشائع بأنّ أي إزاحة تكسر الاستقرار.

مثال (7.7-13).

- **المعطيات:** $f_n(x) = n\,x\,e^{-nx^2}$ على $[0, 1]$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: $x > 0$: الأسّي يهزم $\implies 0$؛ $x = 0$: 0.

٢. الذروة عند $x = \frac{1}{\sqrt{2n}}$ بقيمة $\sqrt{\frac{n}{2}e^{-1/2}} \to \infty$.

٣. لا موحّد (بل قيم متفجّرة). ■

- **النتيجة:** نقطي فقط.

- **الربط بالذكاء الاصطناعي:** «شوكة منفلتة»: عامل مبالغ في التضخيم n يخلق قمماً غير محدودة — تحذير من معاملات قياس تنمو مع التدريب دون تنظيم.

مثال (7.7-14).

- **المعطيات:** $f_n(x) = \frac{\cos(nx)}{1+n^2x^2}$ على $[0, \pi]$.
- **المطلوب:** الموحّد؟
- **الحل:**

١. $|f_n| \le \frac{1}{1+n^2x^2} \le \frac{1}{1+n^2a^2}$ على $[a, \pi]$؛ وقرب الصفر قيمة $f_n(0) = 1$!

٢. $f_n(0) = 1$ لكل n بينما النقطي عند $x > 0$ يعطي $0 \implies$ النهاية متقطعة.

٣. لا موحّد. ■

- **النتيجة:** نقطي فقط؛ الشوكة عند الصفر ثابتة.

- **الربط بالذكاء الاصطناعي:** «قمة الأصل» في دوال النواة (kernel) عند التزامن: اختلاف الطور الصفري يحفظ قيمة عالية عند الصفر — تحذير في تنعيم الإشارات بالالتفاف.

مثال (7.7-15).

- **المعطيات:** $f_n(x) = \arctan(nx)$ على $\mathbb{R}$.
- **المطلوب:** النقطي والموحّد.
- **الحل:**

١. نقطياً: $x > 0 \to \frac{\pi}{2}$؛ $x < 0 \to -\frac{\pi}{2}$؛ $x = 0 \to 0$.

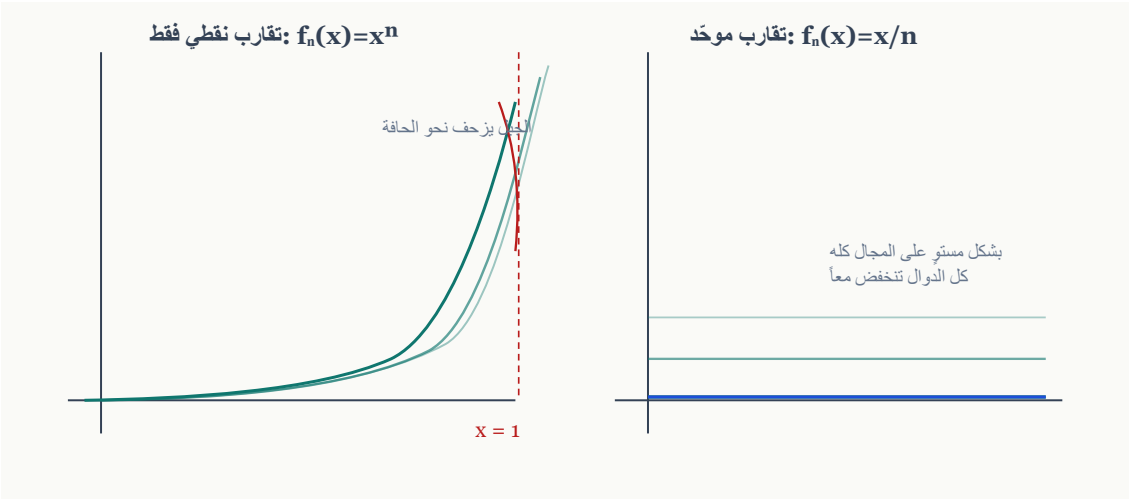
٢. النهاية دالة قفز غير متصلة $\Longrightarrow$ لا موحّد؛ sup يقارب $\frac{\pi}{2}$.

٣. على كل $[a, b]$ بعيداً عن الصفر الموحّد ينجح. ■

- **النتيجة:** نقطي فقط على $\mathbb{R}$؛ موحّد على مجالات مقتطعة.

- **الربط بالذكاء الاصطناعي:** «الاستيفاء بين درجات حرارة»: التقريب النقطي كافٍ بعيداً عن منطقة الانتقال، والمنطقة الحرجة (حدّ القرار) تتطلّب دقّة موحّدة — تركيز التقييم قرب الحدّ.

<figure> الشكل<figcaption> 3.7: يسار — تقارب نقطي فقط: منحنيات x^n «تلتفّ» نحو الحافة والحدّ متقطع.



شكل ٣.٧: *
تقارب نقطي مقابل موحّد

يمين — تقارب موحّد: المنحنيات تنخفض معاً بانتظام على المجال كله.<figcaption/> </figure>

خيط الفصل الواحد

١. δ–ϵ **(2.7)** يمنحنا لغة الدقّة: «خطأ أصغر من ε» — نفس اللغة التي نقيس بها دقّة fp64 مقابل fp16 (فصل 6).

٢. **قوانين النهايات (3.7)** تسمح بتركيب دوالّ من كتل متصلة — نفس تركيب الطبقات في الشبكة.

٣. **الاتصال (4.7)** هو الشرط الذي يحمل انتقالاً صغيراً في المدخل إلى انتقال صغير في الخرج: تعريف **الاستمرارية** بلغة الخسارة.

٤. **نظريات القيم الوسطى (5.7)** تضمن «الوجود»: لكل هدف بين قيمتين يوجد حل — لماذا نثبت الوجود قبل الحساب العددي.

٥. **التقارب المتسلسلي (6.7)** هو لغة خوارزميات التدرّج: $x_k \to x^*$.

٦. **التقارب الموحّد (7.7)** يرفع الضمانة من «لكل نقطة» إلى «لكل النقاط معاً» — الفرق بين أداء شبكة على عيّنة وأدائها المضمون على المجال كله.

جدول الجسور نحو بقية الكتاب

مفهوم هذا الفصل	استخدامه لاحقاً
δ–ϵ	براهين استقرار الخسارة في فصل المتتاليات العليا
الاتصال	شمول العالمية للشبكات (فصل 10)
البولزانو	إثبات وجود حلول لمعادلات التوازن في GAN
شرط كوشي	تقارب SGD/Adam (فصل 40)
التقارب الموحّد	تبديل النهايات في التفاضل الآلي (فصل 36)
$x \log x \to 0$	الإنتروبيا المحدودة (فصل 26)

١. اكتب تعريف δ–ϵ النسبي لـ $\lim_{x\to 1} \frac{1}{x} = 1$ (بتعيين δ بدلالة ε).

٢. أثبت أنّ $\lim_{x\to 0} x \sin \frac{1}{x} = 0$ بتعريف δ–ϵ مباشرة (لا بالحصر).

٣. لكل ε صغير، احسب δ اللازم لـ $f(x) = x^3$ عند $a = 2$.

٤. أثبت أنّ $\lim_{x\to 0} \cos \frac{1}{x}$ لا توجد (باستخدام متتاليتين).

٥. صنّف انقطاعات $f(x) = \frac{x^3 - 8}{x - 2}$ وأصلحها.

٦. صنّف انقطاع $f(x) = e^{1/x}$ عند 0 (ادرس النهايتين الأحاديتين).

٧. أوجد a و b لتكون $f(x) = \begin{cases} ax + b & x < 1 \\ x^2 & x \geq 1 \end{cases}$ متصلة وقابلة للاشتقاق عند 1 (مع استباق الفصل القادم بالميل).

٨. أثبت أنّ كل كثير حدود متصل على $\mathbb{R}$ (من القوانين 2.7).

٩. طبّق البولزانو لإثبات أنّ $x = 2^x$ لها حلّ في $(0, 1)$ ثم في $(0, 2)$: كم حلّاً؟

١٠. أثبت أنّ معادلة $\sin x = x/10$ لها ثلاثة حلول على الأقل في $[-10, 10]$.

١١. ليكن f متصلة على $[0,1]$ بقيم في $[0,1]$. أثبت وجود c بـ $f(c)=c$ (نقطة ثابتة — اسحب $g=f-\mathrm{id}$).

١٢. برهن أنّ $a_n=\frac{3n+1}{n+2}\to 3$ بتعريف (6.7).

١٣. برهن أنّ $a_n=\sqrt[n]{n}\to 1$ (بالتقدير $\ln\sqrt[n]{n}=\frac{\ln n}{n}\to 0$).

١٤. هل $a_n=\cos(n\pi/3)$ كوشي؟ لماذا؟

١٥. برهن أنّ $a_{n+1}=\frac12(a_n+\frac{2}{a_n})$ تقارب إلى $\sqrt2$ لأيّ $a_0>0$ (طريقة هرون).

١٦. افحص التقارب الموحّد لـ $f_n(x)=\frac{n^2x}{1+n^3x^2}$ على $[0,1]$.

١٧. افحص النقطي والموحّد لـ $f_n(x)=\frac{\sin(nx)}{\sqrt n}$ على $\mathbb{R}$، وحدّد هل $\int_0^{\pi}f_n\to 0$.

١٨. اكتب مثالاً مضادّاً: دوال متصلة تتقارب نقطياً إلى حدّ متصل لكن بلا تقارب موحّد (استخدم دوال «سنّ المنشار» المتنقلة).

١٩. أثبت: إذا كانت $f_n\rightrightarrows f$ و $g_n\rightrightarrows g$ على مجموعة محدودة وكانت f,g محدودة، فإنّ $f_ng_n\rightrightarrows fg$.

٢٠. تحدٍّ تركيبي: اجمع بين نظرية البولزانو ومتتالية Bisection لتبرير خوارزمية إيجاد جذر بدقّة ε في $O(\log\frac{b-a}{\varepsilon})$ خطوة، وربطها بحدود الفصل السادس على دقّة fp64.

- **النهاية (1.7):** لعبة δ–ϵ — لكل دقّة خرجٍ ردٌّ بمدخلٍ مناسب.
- **القوانين (2.7):** الجبر على النهايات يصحّ بوجود النهايات؛ حالات عدم التعيين تحتاج أدوات (تحليل، مرافق، لوغاريتم، لاحقاً لوبتال/تايلور).
- **الاتصال (4.7):** $\lim_{x\to a}f(x)=f(a)$ — أربعة أنواع انقطاع، الأول فقط قابل للسدّ.
- **الوجود (5.7):** البولزانو يضمن الجذور؛ EVT يضمن القيم القصوى على المغلقة المحدودة.
- **المتتاليات (6.7)–(8.7):** التقارب والكوشي والضغط — لغة خوارزميات التدرّج.
- **الوظائف (9.7)–(11.7):** النقطي ≠ الموحّد؛ الموحّد هو الذي يحفظ الاتصال ويسمح بتبديل النهايات.

الرمز	المعنى	أين عُرّف
ε,δ	دقّة الخرج ومدى المدخل	(1.7)
$f\in C[a,b]$	متصلة على $[a,b]$	قسم 4.7
$a_n\to L$	تقارب متتالية	(6.7)
كوشي	تساوي الذيل	(7.7)
$f_n\rightrightarrows f$	تقارب موحّد	(9.7)
$\sup_D\lVert f_n-f\rVert$	أسوأ نقطة	(9.7)

١. K. Weierstrass, *Funktionen einer veränderlichen Größe die in Einleitung der Theorie* (محاضرات 1874، صياغة δ–ϵ).

٢. B. Bolzano, *Rein analytischer Beweis des Lehrsatzes...* (1817). — النظرية الوسيطة الأولى بصياغة تحليلية.

٣. W. Rudin, *Principles of Mathematical Analysis*, 3rd ed., McGraw-Hill (الفصل 4: الاستمرارية والاتصال المتسلسل؛ الفصل 7: التقارب الموحّد).

٤. R. Bartle & D. Sherbert, *Introduction to Real Analysis*, 4th ed., Wiley (تعريفات ϵ–δ والتقارب الوظيفي).

٥. H. Robbins & S. Monro, "A Stochastic Approximation Method", *Annals of Mathematical Statistics* 22(3) (1951) — الجدولة a_n المذكورة في الأمثلة.

٦. L. Bottou, F. Curtis & J. Nocedal, "Optimization Methods for Large-Scale Machine Learning", *SIAM Review* 60(2) (2018) — التقارب المتسلسلي لـ SGD.

٧. Y. Abu-Mostafa, M. Magdon-Ismail & H. Lin, *Learning from Data*, AMLBook (2012) — التقارب الموحّد في نظرية التعلم الإحصائي.

٨. N. Higham, *Accuracy and Stability of Numerical Algorithms*, 2nd ed., SIAM (2002) (ربط النهايات بالأخطاء العددية — استمرار للفصل 6).

الاشتقاق وقواعده

الهدف من الفصل

ثاني فصول الجزء الثاني. بنينا في الفصل السابع لغة النهايات والاتصال؛ الآن نصعد درجة واحدة: من «السلوك القرب النقطة» إلى «الميل اللحظي». الاشتقاق هو المحرّك الحقيقي للذكاء الاصطناعي الحديث — كامل التعلّم العميق هو تطبيق متكرر لقاعدة السلسلة التي سنبرهنها هنا.

ثلاثة مواقف من الميدان:

١. **الانتشار العكسي (Backpropagation)** ليس إلا **قاعدة السلسلة** مطبّقة بكفاءة:

$$\frac{\partial L}{\partial W_1} = \frac{\partial L}{\partial a_4} \cdot \frac{\partial a_4}{\partial a_3} \cdots \frac{\partial a_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial W_1}$$

كل محسّن تدرّج (SGD, Adam, RMSProp) يقسم هذا المشتقّ على حجم الدُفعة ويتحرك عكس اتجاهه.

١. **حساب النقاط الحرجة:** أفضل قيم للمعاملات هي حيث $\nabla L = 0$ — نظرياً. لكنّ «النقطة الحرجة» لا تعني حتماً «صغراً»؛ التمييز بين صغرى وكبرى ونقاط سرج يبدأ من المشتقّ الأول والثاني (قسم 6.8).

١. **الدوالّ غير القابلة للاشتقاق في كل مكان:** ReLU و max-pooling و clipping لها زوايا؛ فهم أين يوجد المشتقّ وأين لا يوجد يفسّر لماذا تعمل الـ subgradients ولماذا نستخدم دوالّ ناعمة (GELU, softplus) أحياناً.

خريطة الفصل

القسم	الموضوع	الأداة الأساسية
2.8	تعريف المشتقّ كنهاية	حدّ الفروق
3.8	قواعد الجمع والضرب والقسمة والسلسلة	الجبر التفاضلي
4.8	مشتقّات الدوالّ الأولية	حدّيات مرجعية
5.8	الاشتقاق الضمني والمشتقّات العليا	قاعدة السلسلة العكسية
6.8	نظريات رول والقيمة الوسطى والنقاط الحرجة	رول/MVT
7.8	التجميع: من المشتقّ إلى الانتشار العكسي	تجميع

الحدس

الميل القاطع بين نقطتين a و $a+h$ على منحنى f هو:

$$\text{الميل القاطع} = \frac{f(a+h) - f(a)}{h}$$

كما نُصغّر h يقترب القاطع من **المماس**، وميله يقترب من **المشتقّ**.

التعريف الرسمي

dir="ltr"> <div

Definition 1.2.8 (Derivative). The derivative of f at a is the limit a at dffierentiable

$$f'(a) = \lim_{h \to 0} \frac{f(a+h) - f(a)}{h}$$

Equivalently: (finite). exists

$$f'(a) = \lim_{x \to a} \frac{f(x) - f(a)}{x - a}.$$

$$f'(a) = \lim_{h \to 0} \frac{f(a+h) - f(a)}{h} \tag{1.8}$$

المشتقّان الأحاديان:

$$f'_-(a) = \lim_{h \to 0^-} \frac{f(a+h) - f(a)}{h}, \qquad f'_+(a) = \lim_{h \to 0^+} \frac{f(a+h) - f(a)}{h} \tag{2.8}$$

النظرية 1.2.8 (الاشتقاق $\Longrightarrow$ الاتصال). إذا كانت f قابلة للاشتقاق عند a فإنها متصلة عند a.

البرهان.

$\lim_{x \to a}(f(x) - f(a)) = \lim_{x \to a} \frac{f(x)-f(a)}{x-a} \cdot (x - a) = f'(a) \cdot 0 = 0$. ■

العكس خطأ: $|x|$ متصلة عند 0 وغير قابلة للاشتقاق (الميلان الأحاديان -1 و $+1$).

جدول الرموز

الرمز	الاسم	المعنى
$f'(a)$	مشتقّ لاغرانج	الميل اللحظي عند a
$\frac{df}{dx}\big\|_a$	مشتقّ لايبنيتس	كم يتغيّر f لكل وحدة تغيّر صغيرة في x
h	الزيادة	خطوة صغيرة، $h \to 0$
$f'_{\pm}(a)$	الميلان الأحادية	يمين/يسار النقطة

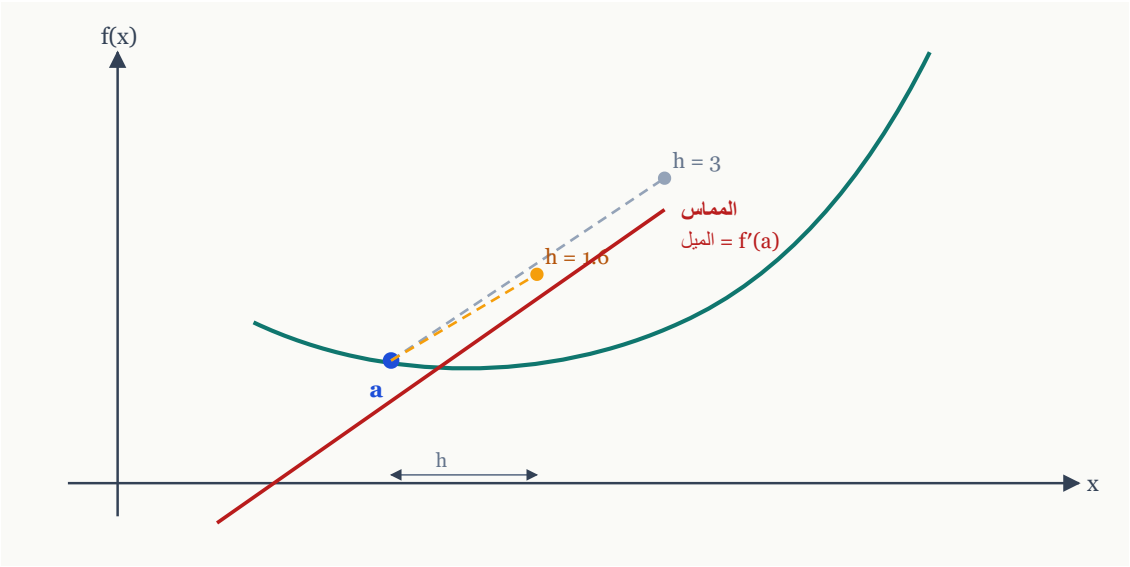
رسم توضيحي

<figure> الشكل<figcaption> 1.8: من القاطع إلى المماس — مع تصغّر h يدور القاطع حول النقطة حتى يستقرّ على المماس، وميله هو $f'(a)$.</figcaption></figure>

أخطاء شائعة في تعريف المشتقّ

الخطأ	لماذا خطأ	التصحيح
«متصلة $\Longrightarrow$ قابلة للاشتقاق»	$\lvert x\rvert$، $\sqrt[3]{x}$، ReLU عند 0	الاتصال ضروري غير كافٍ
«المشتقّ هو الميل بين نقطتين»	ذاك الميل **القاطع**	المشتقّ = نهاية الميول القاطعة
نسيان أنّ المشتقّ دالة	$f'(a)$ قيمة عند نقطة، f' دالة جديدة	المشتقّ له مشتقّ (f'')
حذف الشرط $h \neq 0$ في الحدّ	القسمة على صفر	الحدّ يُدرس عند $h \to 0$ لا $h = 0$

أمثلة محلولة على تعريف المشتقّ (15 مثالاً)



شكل ١٠٨: *
المشتقّ كميل مماس

مثال (1-2.8).

- **المعطيات:** $f(x) = 3x^2 + 1$.
- **المطلوب:** احسب $f'(2)$ من التعريف (1.8).
- **الحل:**

١. $\frac{f(2+h)-f(2)}{h} = \frac{3(2+h)^2+1-13}{h} = \frac{12h+3h^2}{h} = 12 + 3h$.

٢. النهاية عند $h \to 0$: $f'(2) = 12$. ■

- **النتيجة:** 12 — يساوي $6x$ عند $x = 2$.
- **الربط بالذكاء الاصطناعي:** خسارة تربيعية $\|y - \hat{y}\|^2$ لهذا الميل بالضبط؛ لذلك «تدرّجها خطّي في الخطأ» — سلوك الانحدار الخطّي.

مثال (2-2.8).

- **المعطيات:** $f(x) = \frac{1}{x}$.
- **المطلوب:** $f'(a)$ العام من التعريف.
- **الحل:**

١. $\frac{1/(a+h)-1/a}{h} = \frac{a-(a+h)}{h\,a(a+h)} = \frac{-1}{a(a+h)}$.

٢. النهاية: $f'(a) = -\frac{1}{a^2}$ $(a \neq 0)$. ■

- **النتيجة:** $-\frac{1}{a^2}$.

- **الربط بالذكاء الاصطناعي:** تدرّج $1/x$ ينفجر قرب الصفر — السبب العددي نفسه لجمع ϵ في تنظيمات المقام (LayerNorm).

مثال (8.2-3).

- **المعطيات:** $f(x) = \sqrt{x}$.
- **المطلوب:** $f'(a)$ من التعريف عند $a > 0$.
- **الحل:**

١. $\frac{\sqrt{a+h}-\sqrt{a}}{h} = \frac{h}{h(\sqrt{a+h}+\sqrt{a})} = \frac{1}{\sqrt{a+h}+\sqrt{a}}$.

٢. النهاية: $\frac{1}{2\sqrt{a}}$. ■

- **النتيجة:** $f'(a) = \frac{1}{2\sqrt{a}}$.

- **الربط بالذكاء الاصطناعي:** RMSNorm عند القيم الصغيرة: المشتقّ $1/(2\sqrt{a}) \to \infty$ يفسّر الحساسية العددية عند نُرم مُهملة — جمع ϵ يقتطع هذه الشوكة.

مثال (8.2-4).

- **المعطيات:** $f(x) = |x|$.
- **المطلوب:** افحص القابلية للاشتقاق عند 0.
- **الحل:**

١. يميناً: $\frac{h-0}{h} = 1 \to 1$.

٢. يساراً: $\frac{-h-0}{h} = -1 \to -1$.

٣. الميلان مختلفان $\Rightarrow$ لا مشتقّ عند 0 (متصلة رغم ذلك). ■

- **النتيجة:** غير قابلة للاشتقاق عند 0؛ $f' = \operatorname{sgn}(x)$ فيما عدا ذلك.

- **الربط بالذكاء الاصطناعي:** خسارة L1 بالضبط؛ الأطراف تستخدم subgradient (اختيار أي قيمة بين -1 و 1) — عملياً pytorch يعيد sgn.

مثال (8.2-5).

- **المعطيات:** $f(x) = \mathrm{ReLU}(x) = \max(0, x)$.

- **المطلوب:** المشتقّان الأحاديان عند 0 ومناقشة الاختيار.
- **الحل:**

١. $f'_+(0)=1$، $f'_-(0)=0$.

٢. لا مشتقّ عند 0؛ المجموعة الجزئية الجزئية للـ subgradients هي $[0,1]$.

٣. الأطراف الشائعة: 0 (tensorflow) أو 1 (بعض التنفيذات). ■

- **النتيجة:** $f'(x)=\mathbb{1}[x>0]$ عملياً.

- **الربط بالذكاء الاصطناعي:** أيّ قيمة نختار عند الزاوية لا تؤثر نظرياً عند النقاط السرية، لكنها تؤثر عملياً على «وحدات ميتة» (dead ReLU) إذا اخترنا 0 دائماً.

مثال (8.2-6).

- **المعطيات:** $f(x)=x^3$.
- **المطلوب:** $f'(a)$ من التعريف، ولماذا لا توجد «زاوية» عند 0.
- **الحل:**

١. $\frac{(a+h)^3-a^3}{h}=3a^2+3ah+h^2\to 3a^2$.

٢. عند $a=0$: المشتقّ $=0$، والميلان الأحاديان كلاهما 0.

٣. إذن $f'(0)=0$ موجودة — نقطة سلسة (لا زاوية) لكنها نقطة انقلاب (saddle-like). ■

- **النتيجة:** $f'(a)=3a^2$؛ عند 0 مشتقّ صفري مع تغيّر إشارة للمشتقّ.

- **الربط بالذكاء الاصطناعي:** نقاط السرج من هذا النمط (x^3)؛ شهرة خاطئة أنّ $\nabla=0$ يعني قاعاً — لذا نراقب منحنى الخسارة لا قيمة التدرّج وحدها.

مثال (8.2-7).

- **المعطيات:** $f(x)=\sin x$.
- **المطلوب:** $f'(a)$ من التعريف باستخدام الحدّيات المرجعية.
- **الحل:**

١. $\frac{\sin(a+h)-\sin a}{h}=\cos a\cdot\frac{\sin h}{h}-\sin a\cdot\frac{1-\cos h}{h}$.

٢. $\frac{\sin h}{h}\to 1$ و $\frac{1-\cos h}{h}\to 0$.

٣. النتيجة: $f'(a)=\cos a$. ■

- **النتيجة:** $(\sin)'=\cos$.

- **الربط بالذكاء الاصطناعي:** positional encoding الجيبي: تدرّجاته $\sin,\ -\sin$ cos تُغلق دائرة — استقرار الاتجاه عند إزاحات المواضع.

مثال (8-2.8).

- **المعطيات:** $f(x) = e^x$.
- **المطلوب:** $f'(a)$ من التعريف.
- **الحل:**

١. $\frac{e^{a+h}-e^a}{h} = e^a \cdot \frac{e^h-1}{h}$.

٢. الحدّ المرجعي $\frac{e^h-1}{h} \to 1$ (مثال 15-4.7).

٣. النتيجة: $f'(a) = e^a$. ■

- **النتيجة:** e^x دالّة ذاتها مشتقّها — وحيدة بهذه الخاصية (حتى المضاعفات).
- **الربط بالذكاء الاصطناعي:** هذه «الثبات الذاتي» أساس استخدام الأسّ في دوال التنشيط والتفكير في الأنظمة الخطية الزمنية، وأيضاً لماذا softmax مستقر تحليلياً.

مثال (9-2.8).

- **المعطيات:** $f(x) = \ln x$ عند $a > 0$.
- **المطلوب:** $f'(a)$ من التعريف.
- **الحل:**

١. $\frac{\ln(a+h)-\ln a}{h} = \frac{1}{h}\ln\left(1+\frac{h}{a}\right) = \frac{1}{a}\ln\left(1+\frac{h}{a}\right)^{a/h}$.

٢. $\left(1+\frac{h}{a}\right)^{a/h} \to e$ فاللوغاريتم $\to 1$.

٣. النتيجة: $f'(a) = \frac{1}{a}$. ■

- **النتيجة:** $(\ln x)' = \frac{1}{x}$.
- **الربط بالذكاء الاصطناعي:** تدرّج cross-entropy مع softmax يساوي $y - \hat{y}$ — كسور بسيطة بعد اختزال لوغاريتمي، ولهذا يعمل الانتشار العكسي بسلاسة هناك.

مثال (10-2.8).

- **المعطيات:** $f(x) = \begin{cases} x^2 \sin\frac{1}{x} & x \neq 0 \\ 0 & x = 0 \end{cases}$
- **المطلوب:** هل $f'(0)$ موجودة؟
- **الحل:**

١. $\frac{f(h)-f(0)}{h} = h\sin\frac{1}{h}$.

٢. بالضغط: $|h\sin\frac{1}{h}| \le |h| \to 0$.

٣. $f'(0) = 0$ موجودة. لكنّ f' غير متصلة عند 0 (تتذبذب بين ± 1). ■

- **النتيجة:** قابلة للاشتقاق عند 0 لكن المشتقّ غير متصل هناك.

- **الربط بالذكاء الاصطناعي:** «مشتقّ موجود لكن غير متصل» يفسّر تذبذب تدرّجات الشبكات قرب توزيعات المدخلات الحدّية رغم سلاسة الخسارة ظاهرياً.

مثال (8.2-11).

- **المعطيات:** $f(x) = x^{1/3}$.
- **المطلوب:** افحص الاشتقاق عند 0.
- **الحل:**

١. $\frac{h^{1/3}-0}{h} = h^{-2/3} \to +\infty$.

٢. الميل «عمودي» — المماس رأسي.

٣. لا مشتقّ منتهٍ عند 0. ■

- **النتيجة:** مماس عمودي عند 0.

- **الربط بالذكاء الاصطناعي:** خسارة $|w|^{1/2}$ (تنظيم أقوى من L1 لهذا السلوك؛ مشتقّها ينفجر قرب الصفر — لهذا نلجأ لـ proximal methods بدل التدرّج المباشر.

مثال (8.2-12).

- **المعطيات:** $f(x) = \tanh x$.
- **المطلوب:** المشتقّ عند 0 ومناقشة أقصى قيمة.
- **الحل:**

١. $\tanh x = \frac{e^x-e^{-x}}{e^x+e^{-x}}$؛ من الجبر (قسم 4.8): $f'(x) = 1 - \tanh^2 x$.

٢. عند 0: $f'(0) = 1$.

٣. الأقصى عند 0 بالضبط؛ الذيلان $\to 0$. ■

- **النتيجة:** $f'(0) = 1$ وهي القيمة العظمى للمشتقّ.

- **الربط بالذكاء الاصطناعي:** «تلاشي تدرّج»: المشتقّ ≤ 1 ويضمحل أُسّياً في العمق — السبب الأصلي لاختراع LSTM.

مثال (2.8-13).

- **المعطيات:** $f(x) = x^2$.
- **المطلوب:** معامل الاختلاف بين الميل القاطع عند h والمشتقّ عند $a = 1$.
- **الحل:**

١. الميل القاطع $= \frac{(1+h)^2-1}{h} = 2 + h$.

٢. الفرق عن $f'(1) = 2$ هو h بالضبط.

٣. نسبة الخطأ $h/2$: خطأ من الدرجة الأولى. ■

- **النتيجة:** خطأ القاطع $O(h)$.

- **الربط بالذكاء الاصطناعي:** هذا «خطأ الدقة العددية في فرق منته» (فصل 6): حساب التدرّج بالفروق $h = 10^{-8}$ في fp64 يفقد نصف خاناته — والسبب الإلغاء، ولهذا نستخدم backprop التحليلي.

مثال (2.8-14).

- **المعطيات:** $f(x) = \begin{cases} x^2 & x \le 1 \\ 2x - 1 & x > 1 \end{cases}$
- **المطلوب:** هل f قابلة للاشتقاق عند 1؟ (دالة «ملصقة» بسلاسة)
- **الحل:**

١. الاتصال: الطرفان $= 1$ عند $x = 1 \implies$ متصلة.

٢. يساراً: ميل x^2 عند 1 هو 2.

٣. يميناً: ميل $2x - 1$ هو 2 دائماً $\implies$ متساويان $\implies$ **قابلة للاشتقاق** و $f'(1) = 2$. ■

- **النتيجة:** ملصق سلس — قابل للاشتقاق عند نقطة الوصل.

- **الربط بالذكاء الاصطناعي:** هذه تقنية «اللصق السلس» في دوال مثل Huber و softplus: نختار المعاملات ليتساوى القيمة والميل عند نقطة الانتقال.

مثال (2.8-15).

- **المعطيات:** $f(x) = \text{softplus}(x) = \ln(1 + e^x)$.
- **المطلوب:** احسب $f'(x)$ ومناقشة سلوكها عند $\pm\infty$.
- **الحل:**

١. $f'(x) = \frac{e^x}{1+e^x} = \sigma(x)$ (sigmoid).

٢. عند $x \to -\infty$: $f' \to 0$؛ عند $x \to +\infty$: $f' \to 1$.

٣. عند 0: $f'(0) = \frac{1}{2}$ — قيمة ناعمة بدل زاوية ReLU. ■

- **النتيجة:** $(\text{softplus})' = \sigma$ — نسخة ناعمة من ReLU.

- **الربط بالذكاء الاصطناعي:** softplus هو «ReLU القابل للاشتقاق دائماً»؛ يستخدم في توزيعات الانحراف المعياري (VAE) حيث يلزم تدرّج لا صفري في كل مكان.

النظريات

dir="ltr"> <div

(Sum 1.3.8 Theorem $(f \pm g)' = f' \pm g'$ **rule). (Product 2.3.8 Theorem** $(fg)' = f'g + fg'$ **rule). (Quotient 3.3.8 Theorem** $\left(\frac{f}{g}\right)' = \frac{f'g - fg'}{g^2}$ $(g \neq 0)$. **(Chain 4.3.8 Theorem** $(g \circ f)'(x) = g'(f(x)) \cdot f'(x)$ **rule).**

$$(fg)' = f'g + fg' \tag{3.8}$$

$$\left(\frac{f}{g}\right)' = \frac{f'g - fg'}{g^2} \tag{4.8}$$

$$\frac{d}{dx}\, g(f(x)) = g'(f(x)) \cdot f'(x) \tag{5.8}$$

برهان قاعدة السلسلة (بصيغة الاختلافات)

اكتب الاختلافات عند نقطة $u = f(x)$:

$$\Delta u = f'(x)\,\Delta x + \varepsilon_1\,\Delta x, \qquad \Delta g = g'(u)\,\Delta u + \varepsilon_2\,\Delta u,$$

حيث $\varepsilon_i \to 0$ مع $\Delta \to 0$. بالتعويض:

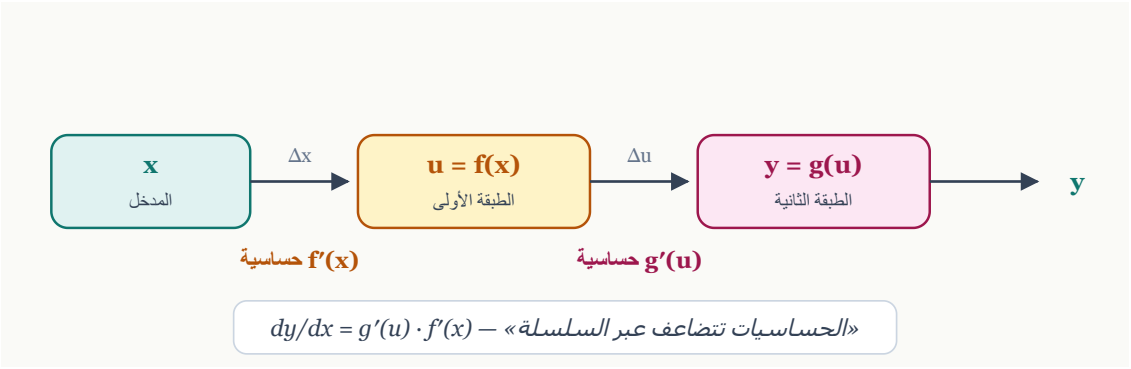
$$\Delta g = g'(u)\,f'(x)\,\Delta x + o(\Delta x) \implies \frac{\Delta g}{\Delta x} \to g'(f(x))\,f'(x). \qquad \blacksquare$$

رسم توضيحي لقاعدة السلسلة

<figure> الشكل<figcaption> 2.8: قاعدة السلسلة نخط أنابيب — التغيير الصغير في x يُضخَّم بمعامل f' ثم بمعامل g'؛ الحاصل الضربي هو حساسية الخرج النهائية. هذا حرفياً «حساب حساسية» في الانتشار العكسي.</figcaption>
</figure>

أخطاء شائعة في قواعد الاشتقاق

الخطأ	لماذا خطأ	التصحيح
$(fg)' = f'g'$	مضاد مثال: $x \cdot x$	قاعدة الضرب (3.8)
$(f \circ g)' = f' \circ g'$	نسيان ضرب مشتقّ الداخل	g' يتضمّن (5.8)
«كل حدّ يشتقّ وحده في حاصل ضرب ثلاثي ثم يُجمع؟»	نعم لكن يجب أن يشتقّ حدّ واحد فقط في كل حدّ مجموع	$(fgh)' = f'gh + fg'h + fgh'$
تطبيق السلسلة على «قوة خارج» دون الداخل	$(\sin^2 x)' \neq 2\sin x$	اكتب $u = \sin x$ ثم u^2
نسيان أنّ ثابتًا مضروباً لا يشتقّ إلى «ثابت»	$(5f)' = 5f'$ لا 5	الثابت المضاعف يخرج كما هو



شكل ٢٠٨: *
قاعدة السلسلة

أمثلة محلولة على قواعد الاشتقاق (15 مثالاً)

مثال (٨.٣-١).

- **المعطيات:** $f(x) = x^2 \sin x$.
- **المطلوب:** $f'(x)$ بقاعدة الضرب.
- **الحل:**

١. $f' = (x^2)' \sin x + x^2 (\sin x)'$.

٢. $f' = 2x \sin x + x^2 \cos x$. ■

- **النتيجة:** $2x \sin x + x^2 \cos x$.

- **الربط بالذكاء الاصطناعي:** نواتج مثل $x^2 \sin x$ تظهر في تفاعل المدخلات مع الترميز الموضعي؛ التدرّج يُفكّك إلى مساهمتين منفصلتين — فكرة «فصل المسارات» في backprop.

مثال (٨.٣-٢).

- **المعطيات:** $f(x) = \dfrac{x}{x^2 + 1}$.
- **المطلوب:** $f'(x)$ بقاعدة القسمة.
- **الحل:**

١. $f' = \dfrac{1 \cdot (x^2 + 1) - x \cdot 2x}{(x^2 + 1)^2}$.

٢. $f' = \dfrac{1 - x^2}{(x^2 + 1)^2}$. ■

- **النتيجة:** $\frac{1-x^2}{(x^2+1)^2}$؛ صفر عند $x = \pm 1$.

- **الربط بالذكاء الاصطناعي:** «بوّابات نافعة» بهذا الشكل الكسوري تتحكم بمرور الإشارة في LSTM؛ صفر المشتقّ يحدّد ذروة المرور.

مثال (3-3.8).

- **المعطيات:** $f(x) = \sin(3x^2)$.
- **المطلوب:** $f'(x)$ بقاعدة السلسلة.
- **الحل:**

١. خارجي $\sin u$، داخلي $u = 3x^2$.

٢. $f' = \cos(3x^2) \cdot 6x$. ■

- **النتيجة:** $6x\cos(3x^2)$.

- **الربط بالذكاء الاصطناعي:** كل معامل متعدّد $(3x^2)$ يخرج كعامل قياس في التدرّج — «تضخيم» داخل الطبقة.

مثال (4-3.8).

- **المعطيات:** $f(x) = e^{-x^2/2}$ (نواة غاوسية).
- **المطلوب:** $f'(x)$.
- **الحل:**

١. خارجي e^u، داخلي $u = -x^2/2$، $u' = -x$.

٢. $f' = e^{-x^2/2} \cdot (-x) = -x\,e^{-x^2/2}$. ■

- **النتيجة:** $-xe^{-x^2/2}$.

- **الربط بالذكاء الاصطناعي:** تدرّج النواة الغاوسية في SVM و attention المبني على المسافة؛ إشارته سالبة للجانب الموجب — «انجذاب» نحو المركز.

مثال (5-3.8).

- **المعطيات:** $f(x) = \sigma(g(x))$ حيث σ الدالة اللوجستية.
- **المطلوب:** برهن $(\sigma \circ g)' = \sigma(g)(1-\sigma(g))\,g'$.
- **الحل:**

١. $(\sigma \circ g)' = \sigma'(g)\,g'$.

٢. $\sigma'(u) = \sigma(u)(1-\sigma(u))$ (مثال 4-4.8).

٣. بالتعويض تنتهي. ■

- **النتيجة:** الصيغة المركّبة السهلة.

- **الربط بالذكاء الاصطناعي:** هذه الصيغة هي «سطر واحد» في backprop عبر طبقة sigmoid: التدرّج يمر مضروباً بـ $\hat{y}(1-\hat{y})$.

مثال (3-8.6).

- **المعطيات:** $f(x) = (2x+1)^5$.
- **المطلوب:** $f'(x)$ بطريقتين (فكّ ثم سلسلة).
- **الحل:**

١. سلسلة: $5(2x+1)^4 \cdot 2 = 10(2x+1)^4$.

٢. فكّ: $f = 32x^5+80x^4+80x^3+40x^2+10x+1$، المشتقّ $= 160x^4+320x^3+240x^2+80x+10$.

٣. مساواة الطريقتين بالتحقق: $10(2x+1)^4$ يتوسع لنفس الحدود. ■

- **النتيجة:** $10(2x+1)^4$ — السلسلة توفّر الجبر.

- **الربط بالذكاء الاصطناعي:** فكّ الأُسّ الخام يقابل «توسيع شبكة عميقة إلى شبكة عريضة»: الجبر ينفجر، السلسلة تبقى خطوات قليلة — لهذا backprop عملي.

مثال (3-8.7).

- **المعطيات:** $f(x) = x^2 e^{3x}$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. ضرب + سلسلة: $f' = 2xe^{3x} + x^2 \cdot 3e^{3x}$.

٢. تجميع: $f' = xe^{3x}(2+3x)$. ■

- **النتيجة:** $xe^{3x}(2+3x)$.

- **الربط بالذكاء الاصطناعي:** نواتج كثيرة حدود مع أسّي تصف قوانين التوسّع؛ تحليل الصفر يحدّد «الطول الأمثل» للسياق.

مثال (3-8.8).

- **المعطيات:** $f(x) = \dfrac{\sin x}{x}$ عند $x \neq 0$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. $f' = \dfrac{x\cos x - \sin x}{x^2}$. ■

- **النتيجة:** $\frac{x\cos x - \sin x}{x^2}$.
- **الربط بالذكاء الاصطناعي:** التدرّج الأول لـ sinc، عند الصفر يحتاج توسّع تايلور ($f'(0) = 0$) — نفس أسلوب «التعويض الحدّي» في تنفيذ دوال خاصة.

مثال (8.3-9).

- **المعطيات:** $f(x) = \ln(1 + e^x)$ (softplus) — مشتقّه مباشرة.
- **المطلوب:** $f'(x)$ بقاعدة السلسلة.
- **الحل:**

١. خارجي $\ln u$، داخلي $u = 1 + e^x$.

٢. $f' = \frac{e^x}{1+e^x} = \sigma(x)$. ■

- **النتيجة:** $f' = \sigma$ — أجمل زوج في التفاضل.
- **الربط بالذكاء الاصطناعي:** backprop عبر softplus يعطي sigmoid مجاناً؛ يستخدم في مخرجات «الانحراف المعياري» في VAE.

مثال (8.3-10).

- **المعطيات:** $f(x) = (x^2 + 1)^{10}$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. سلسلة: $10(x^2 + 1)^9 \cdot 2x$.

٢. $f' = 20x(x^2 + 1)^9$. ■

- **النتيجة:** $20x(x^2 + 1)^9$.
- **الربط بالذكاء الاصطناعي:** «قوة على مجموع مربعات» هي الشكل العام لمشتقّ $\|v\|^{2p}$ في تنظيم الأوزان؛ العامل $2x$ هو «اتجاه الإصلاح».

مثال (8.3-11).

- **المعطيات:** $f(x) = \sqrt{x^2+4}\cdot e^{-x}$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. ضرب: $u = \sqrt{x^2+4}$ $\left(u' = \frac{x}{\sqrt{x^2+4}}\right)$، $v = e^{-x}$ $(v' = -e^{-x})$.

٢. $f' = \frac{x}{\sqrt{x^2+4}}e^{-x} - \sqrt{x^2+4}\,e^{-x} = e^{-x}\left(\frac{x}{\sqrt{x^2+4}} - \sqrt{x^2+4}\right)$.

٣. اختزال: $f' = \frac{e^{-x}(x-(x^2+4))}{\sqrt{x^2+4}} = \frac{-e^{-x}(x^2-x+4)}{\sqrt{x^2+4}}$. ■

- **النتيجة:** $\frac{-e^{-x}(x^2-x+4)}{\sqrt{x^2+4}}$ — دائماً سالبة $(\Delta = 1-16<0)$.

- **الربط بالذكاء الاصطناعي:** «دالة متناقصة دائماً» — نمط مفيد في إثبات عدم وجود محليّات في مسارات معيّنة (تقلّص تدريجي للعوامل).

مثال (8.3-12).

- **المعطيات:** $f(x) = \sin(\cos(\tan x))$.
- **المطلوب:** $f'(x)$ بثلاث طبقات سلسلة.
- **الحل:**

١. خارجي→داخلي→أعمق: $\sin \to \cos \to \tan$.

٢. $f' = \cos(\cos(\tan x))\cdot(-\sin(\tan x))\cdot \sec^2 x$.

٣. $f' = -\sec^2 x\,\sin(\tan x)\cos(\cos(\tan x))$. ■

- **النتيجة:** حاصل ضرب ثلاث حساسيات.

- **الربط بالذكاء الاصطناعي:** «عمق ثلاث طبقات» — لو انهارت إحدى الحساسيات إلى صفر انقطع التدفق كله (vanishing gradient)؛ الشوكة عند $\tan x \to \infty$ هي الانفجار.

مثال (8.3-13).

- **المعطيات:** $f(x) = x^x$ $(x>0)$.
- **المطلوب:** $f'(x)$ بأسّ متغيّر.
- **الحل:**

١. اكتب $f = e^{x \ln x}$.

٢. $f' = e^{x \ln x}(\ln x + 1) = x^x(\ln x + 1)$. ■

- **النتيجة:** $x^x(\ln x + 1)$.

- **الربط بالذكاء الاصطناعي:** الأسّيات المتغيّرة تظهر في تقديرات «عدد المسارات» في المزج بين الخبراء (MoE)؛ اللوغاريتم أولاً دائماً قبل الاشتقاق.

مثال (14-3.8).

- **المعطيات:** $f(x) = \dfrac{e^{2x}}{1+e^{2x}}$ (sigmoid بحدين مضاعفين).
- **المطلوب:** $f'(x)$ والتحقق من المساواة لـ $\sigma(2x)$.
- **الحل:**

١. $f' = 2\sigma(2x)(1-\sigma(2x)) \implies f = \sigma(2x)$.

٢. بقاعدة القسمة مباشرة: $\frac{2e^{2x}}{(1+e^{2x})^2} = \frac{2e^{2x}(1+e^{2x}) - e^{2x} \cdot 2e^{2x}}{(1+e^{2x})^2}$ — نفس القيمة. ■

- **النتيجة:** $2\sigma(2x)(1-\sigma(2x))$.

- **الربط بالذكاء الاصطناعي:** «مضاعفة الحدّ» تضاعف المشتقق؛ معايرة درجة حرارة softmax: الحرارة T تقسم الحدّ وتقسم المشتقق أيضاً.

مثال (15-3.8).

- **المعطيات:** $L(W) = \frac{1}{2}\|WX - y\|_2^2$ حيث W مصفوفة، x, y متجهات.
- **المطلوب:** مشتقّ L بالنسبة إلى W (نسخة مصفوفية للسلسلة — تمهيد للفصل متعدد المتغيرات).
- **الحل:**

١. سلسلة: $\nabla_W L = (WX - y) \cdot \frac{\partial (WX-y)}{\partial W}$.

٢. بالتمثيل السطحي للحواف: $\nabla_W L = (WX - y)\, x^\top$. ■

- **النتيجة:** $\nabla_W L = (\hat{y} - y)x^\top$ — «الخطأ مضروباً في المدخل».

- **الربط بالذكاء الاصطناعي:** هذه هي قاعدة التحديث في كل طبقة خطية: $\Delta W \propto (\hat{y} - y)x^\top$ — قاعدة دلتا (delta rule) وهي قلب backprop كله.

الجدول الأساسي

الدالة	المشتقّ	ملاحظة
c (ثابت)	0	
x^n	$n\,x^{n-1}$	لأيّ عدد حقيقي n
e^x	e^x	ذاتية الاشتقاق
a^x	$a^x \ln a$	$= e^{x \ln a}$
$\ln x$	$\dfrac{1}{x}$	$x > 0$
$\log_a x$	$\dfrac{1}{x \ln a}$	
$\sin x$	$\cos x$	
$\cos x$	$-\sin x$	
$\tan x$	$\sec^2 x = \dfrac{1}{\cos^2 x}$	
$\arctan x$	$\dfrac{1}{1+x^2}$	بلا انفجار!
$\arcsin x$	$\dfrac{1}{\sqrt{1-x^2}}$	
$\sigma(x) = \dfrac{1}{1+e^{-x}}$	$\sigma(1-\sigma)$	قلب اللوجستية

برهان موضعي — مشتقّ السيجمويد:

$$\sigma'(x) = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{1}{1+e^{-x}} \cdot \frac{e^{-x}}{1+e^{-x}} = \sigma(x)\,(1-\sigma(x)) \tag{6.8}$$

برهان موضعي — مشتقّ tanh:

$$(\tanh x)' = 1 - \tanh^2 x \tag{7.8}$$

برهان موضعي — مشتقّ arctan:

من $y = \arctan x \Rightarrow x = \tan y$، وبقاعدة السلسلة العكسية:

$$\frac{dy}{dx} = \frac{1}{\sec^2 y} = \frac{1}{1+\tan^2 y} = \frac{1}{1+x^2} \tag{8.8}$$

أخطاء شائعة في مشتقّات الدوالّ الأولية

الخطأ	لماذا خطأ	التصحيح
$(\ln x)' = \ln x$ أو «ثابت»	اللوغاريتم مشتقّه $1/x$	(الجدول)
$(\tan x)' = \sec x$	نسيان التربيع	$\sec^2 x$
$(\cos x)' = \sin x$	نسيان الإشارة	$-\sin x$
$(x^\pi)' = \pi x^\pi$	نسيان خفض الأس	$\pi x^{\pi-1}$
$(a^x)' = x\,a^{x-1}$	خلط قوة بمتغيّر	$a^x \ln a$

أمثلة محلولة على مشتقّات الدوالّ الأولية (15 مثالاً)

مثال (4.8-1).

- **المعطيات:** $f(x) = x^{3/2}$.
- **المطلوب:** $f'(x)$ (أس كسري).
- **الحل:**

١. $f' = \frac{3}{2}x^{1/2}$.

٢. عند $x = 0$: المشتقّ $0 =$ (من اليمين) — سلس. ■

- **النتيجة:** $\frac{3}{2}\sqrt{x}$.

- **الربط بالذكاء الاصطناعي:** لوغاريتم أُسّ كسري في عقوبات «شبه L1.5» بين L1 و L2 — ضبط قابلية الاشتقاق عند الصفر باختيار الأس.

مثال (4.8-2).

- **المعطيات:** $f(x) = 2^x$.
- **المطلوب:** $f'(x)$ وقيمتها عند 0.
- **الحل:**

١. $f' = 2^x \ln 2$.

٢. عند 0: $\ln 2 \approx 0.693$. ■

- **النتيجة:** $2^x \ln 2$.

- **الربط بالذكاء الاصطناعي:** «لماذا الأساس e خاص؟» — مشتقّه 1 عند الصفر، التطبيع بـ ln في انتروبيا يستخدم الأساس الطبيعي لهذا السبب.

مثال (4.8-3).

- **المعطيات:** $f(x) = \ln(2x + 1)$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. سلسلة: $f' = \frac{2}{2x+1}$. ■

- **النتيجة:** $\frac{2}{2x+1}$.

- **الربط بالذكاء الاصطناعي:** «لوغاريتم داخلي متعدد» — تدرّجات عدد المميزات في softmax المساوي: يُحسب بعد اللوغاريتم لتفادي الإلغاء (log-sum-exp، فصل 6).

مثال (4-4.8).

- **المعطيات:** $\sigma(x) = \frac{1}{1+e^{-x}}$.
- **المطلوب:** برهن (6.8) ثم احسب $\sigma'(0)$ والقيمة العظمى للمشتقّ.
- **الحل:**

١. بقاعدة القسمة أو إعادة الكتابة: $\sigma' = \sigma(1-\sigma)$.

٢. عند 0: $\sigma = \frac{1}{2} \Longrightarrow \sigma'(0) = \frac{1}{4}$.

٣. القيمة العظمى $\frac{1}{4}$ عند 0 (تفتيش داخلي بسيط). ■

- **النتيجة:** $\sigma'(0) = \frac{1}{4}$، والحد الأقصى للمشتقّ $\frac{1}{4}$.
- **الربط بالذكاء الاصطناعي:** «أقصى تمرير $\frac{1}{4}$ لكل طبقة sigmoid» — ضرب $\frac{1}{4}$ عبر 10 طبقات يعطي 10^{-6}: انهيار التدرّج التاريخي الذي قاد إلى ReLU.

مثال (5-4.8).

- **المعطيات:** $f(x) = \tanh x$.
- **المطلوب:** برهن (7.8) وقارن الحد الأقصى للمشتقّ مع sigmoid.
- **الحل:**

١. $\tanh = \frac{e^x - e^{-x}}{e^x + e^{-x}}$؛ بالقسمة: $f' = 1 - \tanh^2 x$.

٢. الحد الأقصى عند 0: 1.

٣. يقارن بـ sigmoid: أربعة أضعاف (1 مقابل $\frac{1}{4}$). ■

- **النتيجة:** $(\tanh)' = 1 - \tanh^2$؛ الذروة 1.
- **الربط بالذكاء الاصطناعي:** لهذا فضّلت شبكات 1998–2015 الـ tanh على sigmoid في الطبقات الخفية — مرور تدرّج أقوى.

مثال (6-4.8).

- **المعطيات:** $f(x) = \arctan x$.
- **المطلوب:** برهن (8.8) وناقش سلوك الذيل.
- **الحل:**

١. من $x = \tan y$ والسلسلة العكسية: $f' = \frac{1}{1+x^2}$.

٢. الذيل: $f' \approx \frac{1}{x^2}$ — يتلاشى بسرعة.

٣. عند 0: $f' = 1$ أقصى قيمة. ■

- **النتيجة:** $\frac{1}{1+x^2}$.

- **الربط بالذكاء الاصطناعي:** «تحوّل بلا انفجار»: أركتان له مشتقّ محدود دائماً — يستخدم في تدرّج الزوايا وتطبيع الاتجاهات في الأنظمة الجيومكانية.

مثال (8.4-7).

- **المعطيات:** $f(x) = x \ln x$ $(x > 0)$.
- **المطلوب:** $f'(x)$ ونقطة الصفر.
- **الحل:**

١. $f' = \ln x + 1$.

٢. صفر عند $x = e^{-1}$. ■

- **النتيجة:** $\ln x + 1$، صغرى الدالة عند e^{-1}.

- **الربط بالذكاء الاصطناعي:** $p \ln p$ في الإنتروبيا: ميله عند $p = e^{-1}$ يحدّد «أحسّ احتمال فردي» من منظور المساهمة السلبية في الإنتروبيا.

مثال (8.4-8).

- **المعطيات:** $f(x) = e^{-\lambda x}$ $(\lambda > 0)$.
- **المطلوب:** $f'(x)$ وثبات النسبة.
- **الحل:**

١. $f' = -\lambda e^{-\lambda x}$.

٢. النسبة $f'/f = -\lambda$ ثابتة — «تفكك أُسّي بمعدّل ثابت». ■

- **النتيجة:** $-\lambda e^{-\lambda x}$.

- **الربط بالذكاء الاصطناعي:** «تلاشي الذاكرة بمعدّل ثابت» في RNN الأصلية — تحليل أثر الضرب المتكرر بمعامل $\lambda < 1$.

مثال (8.4-9).

- **المعطيات:** $f(x) = \ln|x|$.
- **المطلوب:** $f'(x)$ على المجموعتين $x > 0$ و $x < 0$.
- **الحل:**

١. $x > 0$: $f' = \frac{1}{x}$.

٢. $x < 0$: $f' = \frac{1}{x}$ (بالمعامل $|x| = -x$).

٣. إذن $(\ln|x|)' = \frac{1}{x}$ في كلٍّ من المجالين، بلا تعريف عند 0. ■

- **النتيجة:** $\frac{1}{x}$ على كلا الفرعين.

- **الربط بالذكاء الاصطناعي:** نواة kernel (فصل SVM) بمدخل سلبي محتمل: استخدام $\ln|x|$ بدل $\ln x$ يتجنّب NaN في التنفيذ.

مثال (8.4-10).

- **المعطيات:** $f(x) = \sin^2 x$.
- **المطلوب:** $f'(x)$ بطريقتين.
- **الحل:**

١. سلسلة: $2\sin x \cos x$.

٢. هوية: $\sin^2 x = \frac{1-\cos 2x}{2} \Rightarrow f' = \sin 2x$.

٣. المساواة: $2\sin x\cos x = \sin 2x$. ■

- **النتيجة:** $\sin 2x$.

- **الربط بالذكاء الاصطناعي:** «تبسيط قبل الاشتقاق» يوفّر حساباً — نفس فلسفة الاختزال في backprop قبل الحساب العددي.

مثال (8.4-11).

- **المعطيات:** $f(x) = xe^{-x}$.
- **المطلوب:** $f'(x)$ ونقطة الذروة.
- **الحل:**

١. $f' = e^{-x}(1-x)$.

٢. صفر عند $x = 1$ — ذروة «كثافة بواسون النمطية» عند متوسطها. ■

- **النتيجة:** $e^{-x}(1-x)$، ذروة عند 1.

- **الربط بالذكاء الاصطناعي:** توزيع بواسون/غاما في نمذجة «عدد الصناديق الجديدة»؛ الذروة عند المتوسط تُستخدم في تهيئة عوامل التوزيع.

مثال (8.4-12).

- **المعطيات:** $f(x) = \log_2 x$.
- **المطلوب:** $f'(x)$ وقارن مع $\ln x$.
- **الحل:**

١. $f' = \frac{1}{x \ln 2} \approx \frac{1.443}{x}$.

٢. أكبر من مشتقّ اللوغاريتم الطبيعي بعامل $\frac{1}{\ln 2}$. ■

- **النتيجة:** $\frac{1}{x \ln 2}$.

- **الربط بالذكاء الاصطناعي:** إنتروبيا «بالبت» مقابل «النات» — العامل $\ln 2$ فقط؛ نتائج التدريب لا تتأثر إلا بمقياس التدرّج الأولي.

مثال (8.4-13).

- **المعطيات:** $f(x) = \arcsin x$ على $(-1, 1)$.
- **المطلوب:** $f'(x)$ وسلوكها عند الأطراف.
- **الحل:**

١. من $x = \sin y$: $f' = \frac{1}{\cos y} = \frac{1}{\sqrt{1-x^2}}$.

٢. عند الأطراف $\to \infty$ — انفجار. ■

- **النتيجة:** $\frac{1}{\sqrt{1-x^2}}$.

- **الربط بالذكاء الاصطناعي:** قصّ «المساحات المماسية» عند الأطراف (clipping) مطلوب دائماً؛ تقريب $1 - x^2$ قرب 1 يُفقد الدقّة — استخدم asqrt1px2 عند توفره.

مثال (8.4-14).

- **المعطيات:** $f(x) = \ln(\ln x)$ $(x > 1)$.
- **المطلوب:** $f'(x)$.
- **الحل:**

١. سلسلة: $f' = \frac{1}{\ln x} \cdot \frac{1}{x} = \frac{1}{x \ln x}$. ■

- **النتيجة:** $\frac{1}{x \ln x}$.

- **الربط بالذكاء الاصطناعي:** هذا هو «مشتقّ محاسبة الاهتمام على عمق مزدوج» — نمط لوغاريتم-لوغاريتم في قوانين التوسّع (scaling laws) كثيرة الأُسّ.

مثال (15-4.8).

- **المعطيات:** $f(x) = \mathrm{GELU}(x) = x\,\Phi(x)$ مع $\Phi(x) \approx \sigma(1.702x)$ (تقريب sigmoid الشائع).
- **المطلوب:** $f'(x)$ بالتقريب وقارن سلوكها مع ReLU.
- **الحل:**

١. $f' \approx \sigma(1.702x) + x \cdot 1.702\,\sigma(1.702x)(1-\sigma(1.702x))$.

٢. عند $x \to -\infty$: الحدّ الأول $\to 0$ والثاني $\to 0$ (أسّيّاً) — سلس.

٣. عند $x \to +\infty$: $\to 1$ مثل ReLU. ■

- **النتيجة:** نسخة ناعمة تماماً من مشتقّ ReLU.

- **الربط بالذكاء الاصطناعي:** GELU في المحوّلات (transformers) — سلاسة المشتقّ تُلاحظ في ثبات تدرّجات النماذج الضخمة مقارنة بـ ReLU القابل للزوايا.

الاشتقاق الضمني

عندما تربط معادلة $F(x,y) = 0$ بين x و y ضمنياً (بلا حلّ صريح لـ y)، نشتقّ الطرفين بالنسبة إلى x معتبرين $y = y(x)$، ونطبّق السلسلة على كل حدّ فيه y:

$$\frac{d}{dx}F(x,y(x)) = 0 \quad \Longrightarrow \quad \text{حلّ معادلة جبرية لـ } \frac{dy}{dx} \tag{9.8}$$

المشتقّات العليا

$$f''(x) = \frac{d}{dx}f'(x), \qquad f^{(n)}(x) = \frac{d^n}{dx^n}f(x) \tag{10.8}$$

النظرية 1.5.8. $(e^{\lambda x})^{(n)} = \lambda^n e^{\lambda x}$؛ $(\sin x)^{(n)} = \sin\left(x + \frac{n\pi}{2}\right)$.

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اشتقاق y^2 كـ $2y$	نسيان أنّ $y = y(x)$	السلسلة على الدالة الضمنية — $2y\,y'$
نسيان اشتقاق ثابت C في المعادلة الضمنية	يختفي الحدّ	$C' = 0$
f'' يحسب مرة واحدة	الاشتقاق مرتان متتاليتان	ثبّت f' كدالة ثم اشتقّ
الخلط بين $f'' = 0$ و«نقطة انعطاف»	يجب أن يتغيّر إشارة f''	فحص الإشارة حول النقطة

أمثلة محلولة على الاشتقاق الضمني والمشتقّات العليا (15 مثالاً)

مثال (5.8-1).

- **المعطيات:** $x^2 + y^2 = 25$ (دائرة).
- **المطلوب:** $\frac{dy}{dx}$ ضمنياً عند النقطة $(3, 4)$.
- **الحل:**

١. اشتقاق الطرفين: $2x + 2y\,y' = 0$.

٢. $y' = -\frac{x}{y} = -\frac{3}{4}$. ■

- **النتيجة:** $-\frac{3}{4}$ — ميل عمودي على نصف القطر.

- **الربط بالذكاء الاصطناعي:** «قيد دائري» على متجه الأوزان: التدرّج المسموح يقع مماسياً — أساس إسقاط التدرّج (gradient projection) في WGAN.

مثال (5.8-2).

- **المعطيات:** $xy = 1$ (yperbola).
- **المطلوب:** y' ضمنياً وتحقّق بالحلّ الصريح.
- **الحل:**

١. ضمنياً: $y + xy' = 0 \Rightarrow y' = -\frac{y}{x}$.

٢. صراحةً $y = \frac{1}{x}$: $y' = -\frac{1}{x^2}$.

٣. مساواة: $-\frac{1/x}{x} = -\frac{y}{x}$. ■

- **النتيجة:** $y' = -1/x^2$ بطريقتين.

- **الربط بالذكاء الاصطناعي:** «المتتبّع الضمني» مفيد عندما لا يوجد حلّ صريح — نفس مبدأ الاشتقاق الضمني في طبقات deep equilibrium models (DEQ).

مثال (5.8-3).

- **المعطيات:** $e^{xy} = x + y$.
- **المطلوب:** y' عند النقطة $(0, 1)$.
- **الحل:**

١. اشتقاق: $e^{xy}(y + xy') = 1 + y'$.

٢. عند $(0,1)$: $e^{0}(1+0) = 1 + y' \Rightarrow y' = 0$. ■

- **النتيجة:** $y' = 0$ — نقطة مماس أفقي.

- **الربط بالذكاء الاصطناعي:** نقاط «تدرّج صفري» على منحنيات القيد — لحظة توقف صامتة للمحسّن إذا اعتمدنا الميل وحده.

مثال (8.5-4).

- **المعطيات:** $x^3 + y^3 = 6xy$ (فوليوم الحلزون).

- **المطلوب:** y' عام.

- **الحل:**

١. $3x^2 + 3y^2 y' = 6y + 6xy'$.

٢. تجميع: $y'(3y^2 - 6x) = 6y - 3x^2$.

٣. $y' = \frac{2y - x^2}{y^2 - 2x}$. ■

- **النتيجة:** $\frac{2y-x^2}{y^2-2x}$ (عندما يكون المقام غير صفري).

- **الربط بالذكاء الاصطناعي:** «حساسية متغيّر ضمني» في الطبقات المفاهيمية (concept layers): النسبة بين تدرّجين جزئيين تحلّ محلّ الحلّ الصريح.

مثال (8.5-5).

- **المعطيات:** $\sin(xy) = x$.

- **المطلوب:** y'.

- **الحل:**

١. $\cos(xy)(y + xy') = 1$.

٢. $y' \, x\cos(xy) = 1 - y\cos(xy)$.

٣. $y' = \frac{1 - y\cos(xy)}{x\cos(xy)}$. ■

- **النتيجة:** كما أعلاه.

- **الربط بالذكاء الاصطناعي:** دوالّ دورية ضمنية تصف «دورات» في مسارات GAN؛ الميل الضمني يقدّر حساسية الطور.

مثال (5.8-6).

- **المعطيات:** $f(x) = x^2 e^x$.
- **المطلوب:** f'' وعند أي نقطة $f'' = 0$.
- **الحل:**

١. $f' = e^x(x^2 + 2x)$.

٢. $f'' = e^x(x^2 + 4x + 2)$.

٣. صفر عند $x = -2 \pm \sqrt{2}$. ■

- **النتيجة:** $e^x(x^2 + 4x + 2)$، جذران للانعطاف.
- **الربط بالذكاء الاصطناعي:** «تقوّس الخسارة» $f'' > 0$ يحدّد منطقة الاكتئاب (قاع محدّب) — شرط ضمان تقارب SGD محلياً بمعدّل تعلّم صغير.

مثال (5.8-7).

- **المعطيات:** $f(x) = \ln x$.
- **المطلوب:** f'' وإشارتها.
- **الحل:**

١. $f' = \frac{1}{x} > 0$، $f'' = -\frac{1}{x^2} < 0$ دائماً.

٢. اللوغاريتم **مقعّر** (concave) في كل مجاله. ■

- **النتيجة:** $-1/x^2$ — مقعّرية كلية.
- **الربط بالذكاء الاصطناعي:** مقعّرية ln تضمن أنّ «الاستفادة الحدّية متناقصة» — أساس برهان إمكانية فريد كلاسيكي، وتحليل عائد زيادة البيانات المتناقص.

مثال (5.8-8).

- **المعطيات:** $f(x) = e^{\lambda x}$.
- **المطلوب:** $f^{(n)}$.
- **الحل:**

١. $f' = \lambda e^{\lambda x}$، $f'' = \lambda^2 e^{\lambda x}$، ...

٢. بالاستقراء: $f^{(n)} = \lambda^n e^{\lambda x}$. ■

- **النتيجة:** $\lambda^n e^{\lambda x}$.
- **الربط بالذكاء الاصطناعي:** «طيف مشتقّات» للأسّي: كل اشتقاق يضاعف λ — في تحليل Adam، n=عدد الحقب يعطي نموّاً هندسياً للإشارات المكوّنة.

مثال (8.5-9).

- **المعطيات:** $f(x) = \sin x$.
- **المطلوب:** $f^{(n)}$ بصيغة مغلقة.
- **الحل:**

١. $f' = \cos x = \sin(x + \frac{\pi}{2})$.

٢. تكراراً: $f^{(n)} = \sin(x + \frac{n\pi}{2})$.

٣. الدورة 4. ■

- **النتيجة:** $\sin(x + \frac{n\pi}{2})$.

- **الربط بالذكاء الاصطناعي:** «دورة مشتقّات» في الترميز الجيبي: تدوير الطور مع كل اشتقاق — يُستخدم في تمييز المسارات الزمنية للإشارات.

مثال (8.5-10).

- **المعطيات:** $f(x) = \frac{1}{1-x}$ على $|x| < 1$.
- **المطلوب:** $f^{(n)}$ وربطها بمتسلسلة هندسية.
- **الحل:**

١. $f' = \frac{1}{(1-x)^2}$، $f'' = \frac{2}{(1-x)^3}$، ...

٢. $f^{(n)} = \frac{n!}{(1-x)^{n+1}}$.

٣. عند $x = 0$: قيمها $n!$ — معاملات المتسلسلة الهندسية. ■

- **النتيجة:** $\frac{n!}{(1-x)^{n+1}}$.

- **الربط بالذكاء الاصطناعي:** معاملات تايلور تساوي المشتقّات على $n!$ — أول برهان «توسيع دالة إلى سلسلة» يستخدمه فصل تايلور القادم لتفسير GELU.

مثال (8.5-11).

- **المعطيات:** $x^2 + y^2 = 1$.
- **المطلوب:** y'' ضمنياً.
- **الحل:**

١. من $2x + 2yy' = 0$: $y' = -\frac{x}{y}$.

٢. اشتقّ: $-\frac{1}{y^3} = -\frac{x^2+y^2}{y^3} = -\frac{y+x^2/y}{y^2} = -\frac{y-xy'}{y^2} = y''$.

٣. سالبة دائماً — الدائرة «مقعّرة نحو المركز». ■

- **النتيجة:** $-\frac{1}{y^3}$.
- **الربط بالذكاء الاصطناعي:** «تقوّس القيد» يحدّد ثبات إسقاط التدرّج؛ تقوّس سالب قوي يعني «مساراً مُحاطاً».

مثال (12-5.8).

- **المعطيات:** $y = f(x)$ تحقّق $y' + y = e^{-x}$ مع $y(0) = 1$.
- **المطلوب:** إثبت أنّ $y = e^{-x}(x+1)$ حلّ، وأوجد y'' عند 0.
- **الحل:**

١. تحقّق: $y' = -e^{-x}(x+1) + e^{-x} = -xe^{-x}$؛ $y' + y = e^{-x}(1 - x + x + 1)$... دقّة: $-xe^{-x} + e^{-x}(x+1) = e^{-x}$. ✓

٢. $y'' = (x-1)e^{-x}$؛ عند 0: $y'' = -1$. ■

- **النتيجة:** $y''(0) = -1$.
- **الربط بالذكاء الاصطناعي:** معادلات تفاضلية من الدرجة الأولى تصف «تدفّق التدرّج» (gradient flow)؛ اختبار الحلّ مرّكباً — نمط التحقّق في براهين التقارب.

مثال (13-5.8).

- **المعطيات:** $f(x) = x \arctan x$.
- **المطلوب:** f'' وقيمة $f''(0)$.
- **الحل:**

١. $f' = \arctan x + \frac{x}{1+x^2}$.

٢. $f'' = \frac{1}{1+x^2} + \frac{(1+x^2)-2x^2}{(1+x^2)^2} = \frac{2}{(1+x^2)^2}$.

٣. $f''(0) = 2$. ■

- **النتيجة:** $\frac{2}{(1+x^2)^2}$؛ عند الصفر 2.
- **الربط بالذكاء الاصطناعي:** دوالّ «بإشارة تقوّس موجبة دائماً» (محدّبة) — مثالية كعقوبات (regularizers) لأنّها تملك صغرى وحيدة.

مثال (14-5.8).

- **المعطيات:** $f(x) = \sigma(x)$ (سيجمويد).
- **المطلوب:** f'' وبحث إشارتها (نقطة انعطاف).
- **الحل:**

١. $f' = \sigma(1-\sigma)$.

٢. $f'' = \sigma'(1-2\sigma) = \sigma(1-\sigma)(1-2\sigma)$.

٣. الإشارة تتغيّر عند $\sigma = \frac{1}{2}$ أي $x = 0$ — نقطة انعطاف. ■

- **النتيجة:** انعطاف عند 0، محدّبة قبلها ومقعّرة بعدها.
- **الربط بالذكاء الاصطناعي:** sigmoid «محدّبة في الذيل السالب ومقعّرة في الموجب» — هذا الخليط يجعل الخسارة اللوجستية غير محدّبة عالمياً في الشبكات العميقة.

مثال (15-5.8).

- **المعطيات:** $L(\theta) = \theta^4$.
- **المطلوب:** L'، L''، وتحليل النقطة $\theta = 0$.
- **الحل:**

١. $L' = 4\theta^3$، الصفر عند $\theta = 0$ فقط.

٢. $L'' = 12\theta^2 \geq 0$، عند 0: $L'' = 0$ — اختبار المشتقّ الثاني محايد.

٣. ومع ذلك: $L \geq 0$ و $L(0) = 0 \Longrightarrow$ صغرى عالمية (من الإشارة لا من الاختبار). ■

- **النتيجة:** صغرى عالمية عند 0 رغم $L''(0) = 0$.
- **الربط بالذكاء الاصطناعي:** «وادي مسطّح للدرجة الرابعة» — المحسّنات تتباطأ قرب النقطة (تدرّج $4\theta^3$ يخفت)؛ من هنا تبرير التدريج الرابع (quartic) في تحليل الشحاذة الفائقة (over-parameterized minima).

النظريات

dir="ltr"> <div

Theorem 1.6.8 (Rolle). If f is continuous on $[a,b]$, differentiable on (a,b), and $f(a) = f(b)$, then $\exists c \in (a,b) : f'(c) = 0$.

Theorem 2.6.8 (Mean Value — Lagrange). If f is continuous on $[a,b]$ and differentiable on (a,b), then

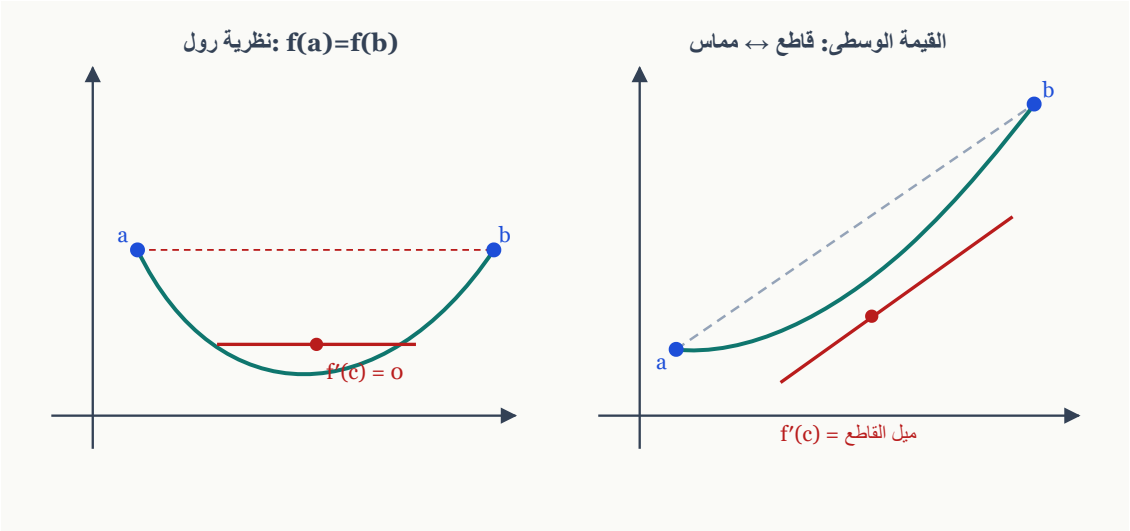
$$\exists\, c \in (a,b) : \quad f'(c) = \frac{f(b) - f(a)}{b - a}.$$

$$f(b) - f(a) = f'(c)\,(b-a) \quad \text{لنقطة} c \in (a,b) \tag{11.8}$$

النظرية 3.6.8 (اختبار المشتقّ الأول). عند نقطة حرجة c (بها $f'(c) = 0$ أو المشتقّ غير موجود): تغيّر إشارة f' من $-$ إلى $+$ يعطي كبرى محلية، ومن $+$ إلى $-$ صغرى محلية.

النظرية 4.6.8 (اختبار المشتقّ الثاني). إذا كانت $f'(c) = 0$ و $f''(c) > 0$ فكبرى... بل **صغرى** محلية؛ و $f''(c) < 0$ كبرى محلية.

<figure> الشكل<figcaption> 3.8: يسار — نظرية رول: قيمتان متساويتان على الطرفين تفرضان نقطة مماس



شكل ٣.٨: *
رول والقيمة الوسطى

أفقي. يمين — القيمة الوسطى: يوجد دائمًا مماس يوازي القاطع الواصل بين الطرفين.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«$f' = 0$ يعني صغرى»	نقاط سرج: x^3 عند 0	فحص تغيّر الإشارة أو f''
«$f'' = 0$ يعني انعطافًا»	x^4 عند 0: $f'' = 0$ وبدون انعطاف	انعطاف = تغيّر إشارة f''
تطبيق MVT دون الاتصال على $[a,b]$	المثال المضاد: دالة قافزة	تحقّق من الفرضيّات
«MVT» يعطي كل النقاط	يعطي وجود نقطة واحدة على الأقل	لا يحدّد عددها

أمثلة محلولة على رول والقيمة الوسطى والنقاط الحرجة (15 مثالاً)

مثال (1-6.8).

- **المعطيات:** $f(x) = x^2 - 4x + 3$ على $[0, 4]$.
- **المطلوب:** نقطة رول c (لاحظ $f(0) = f(4) = 3$).
- **الحل:**

١. $f' = 2x - 4 = 0 \Rightarrow c = 2$.

٢. $2 \in (0,4)$ ✓ و f متصلة وقابلة للاشتقاق. ■

- **النتيجة:** $c = 2$ — رأس القوس (الصغرى).

- **الربط بالذكاء الاصطناعي:** «قوس مربّع بقيم متساوية على الطرفين» هو مصفوفة خسارة تكلفة متساوية عند نقطتين — وجود قاع بينهما مضمون بروول.

مثال (٨.٦-2).

- **المعطيات:** $f(x) = x^3 - 3x$ على $[-\sqrt{3}, \sqrt{3}]$.
- **المطلوب:** نقاط رول.
- **الحل:**

١. $f(\pm\sqrt{3}) = 0$ متساوية.

٢. $f' = 3x^2 - 3 = 0 \Rightarrow x = \pm 1$.

٣. كلتاهما داخل الفترة. ■

- **النتيجة:** $c = \pm 1$.

- **الربط بالذكاء الاصطناعي:** دالة «مزدوجة الآبار» — صورة نموذجية للخسائر ذات حلّين محليين متساويين في مسائل التوليد.

مثال (٨.٦-3).

- **المعطيات:** $f(x) = x^2$ على $[1, 3]$.
- **المطلوب:** نقطة القيمة الوسطى (٨.١١).
- **الحل:**

١. الميل القاطع $= \frac{9-1}{2} = 4$.

٢. $f'(c) = 2c = 4 \Rightarrow c = 2$.

٣. $2 \in (1,3)$ ✓. ■

- **النتيجة:** $c = 2$ — منتصف الفترة (لطبيعة التربيعية).

- **الربط بالذكاء الاصطناعي:** «متوسط السرعة = سرعة لحظية ما في الوسط» يقابل «متوسط الخسارة على الحقب = ميل لحظي ما» — ربط مفهومي للقياس الزمني في التدريب.

مثال (8.6-4).

- **المعطيات:** $f(x) = \ln x$ على $[1, e]$.
- **المطلوب:** c الذي يحقق MVT.
- **الحل:**

١. الميل القاطع $= \frac{1-0}{e-1} = \frac{1}{e-1}$.

٢. $f'(c) = \frac{1}{c} = \frac{1}{e-1} \Rightarrow c = e - 1$.

٣. $e - 1 \approx 1.718 \in (1, e)$ ✓. ■

- **النتيجة:** $c = e - 1$.

- **الربط بالذكاء الاصطناعي:** «أين يساوي ميل اللوغاريتم متوسطه؟» — تحليل معدّل نموّ القياسات اللوغاريتمية في قوانين التوسّع.

مثال (8.6-5).

- **المعطيات:** $f(x) = |x|$ على $[-1, 2]$.
- **المطلوب:** لماذا لا يُطبَّق MVT مباشرة؟ وهل النتيجة صحيحة على أي حال؟
- **الحل:**

١. f متصلة على $[-1, 2]$ لكنها **غير قابلة للاشتقاق** عند 0 داخل الفترة.

٢. فرضيات MVT تنهار (جزئياً).

٣. ومع ذلك توجد c تحقق الميل $\frac{2-1}{3} = \frac{1}{3}$: أيّ $c \in (0, 2)$ حيث $f' = 1 \neq \frac{1}{3}$... لا توجد! لكن على $[-1, 0]$ المشتقّ -1... فلا يوجد c. **MVT فشل فعلاً.** ■

- **النتيجة:** MVT لا يسري؛ الميلان الأحاديان $-1, 1$ لا يحتويان $\frac{1}{3}$.

- **الربط بالذكاء الاصطناعي:** الخسارة $|w|$ (L1): «متوسط التقدّم» قد لا يقابله أيّ تدرّج لحظي — لهذا يعمل L1 ببرمجة محدّبة وليس تدرّجاً ساذجاً.

مثال (8.6-6).

- **المعطيات:** $f(x) = x^3 - 3x^2 + 1$.
- **المطلوب:** النقاط الحرجة وتصنيفها (اختبار المشتقّ الأول).
- **الحل:**

١. $f' = 3x^2 - 6x = 3x(x-2) = 0 \Rightarrow x = 0, 2$.

٢. عند 0: الإشارة $+ \to - \implies$ كبرى محلية $(f = 1)$.

٣. عند 2: الإشارة $- \to + \implies$ صغرى محلية $(f = -3)$. ■

- **النتيجة:** كبرى عند $(0, 1)$، صغرى عند $(2, -3)$.

- **الربط بالذكاء الاصطناعي:** «حوضان» في الخسارة — الوصول للكبرى الوسيطة يمنع الانتقال بين الحوضين؛ لهذا يُضاف «اندفاع» (momentum) لتجاوز العوائق.

مثال (٨.٦-7).

- **المعطيات:** $f(x) = x^4 - 4x^2$.

- **المطلوب:** النقاط الحرجة باختبار المشتقّ الثاني.

- **الحل:**

١. $f' = 4x^3 - 8x = 4x(x^2 - 2) = 0 \Rightarrow x = 0, \pm\sqrt{2}$.

٢. $f'' = 12x^2 - 8$: عند $\pm\sqrt{2}$: $= 16 > 0 \implies$ صغران.

٣. عند 0: $= -8 < 0 \implies$ كبرى. ■

- **النتيجة:** صغران عند $\pm\sqrt{2}$ (قيم -4)، كبرى عند 0 (قيمة 0).

- **الربط بالذكاء الاصطناعي:** «قاعان متماثلان وسرج وسطي» — هندسة W-shape في خسائر ضغط النماذج؛ من نقطة 0 يهرب التدرّج لأحد القاعين عشوائياً (كسر تماثل).

مثال (٨.٦-8).

- **المعطيات:** $f(x) = x + \frac{1}{x}$ على $x > 0$.

- **المطلوب:** الصغرى المحلية.

- **الحل:**

١. $f' = 1 - \frac{1}{x^2} = 0 \Rightarrow x = 1$ (في المجال الموجب).

٢. $f'' = \frac{2}{x^3} > 0 \implies$ صغرى.

٣. $f(1) = 2$. ■

- **النتيجة:** صغرى قيمة 2 عند $x = 1$.

- **الربط بالذكاء الاصطناعي:** «مقايضة» كلاسيكية: خطأ x + تعقيد $\frac{1}{x}$ — تقليل المجموع يعطي التوازن الأمثل (bias-variance) بنسخة منتهية).

مثال (8.6-9).

- **المعطيات:** $f(x) = \sin x$ على $[0, 2\pi]$.
- **المطلوب:** MVT ثم تفسيره هندسياً.
- **الحل:**

١. الميل القاطع $= \frac{0-0}{2\pi} = 0$.

٢. $f'(c) = \cos c = 0 \Rightarrow c = \frac{\pi}{2}, \frac{3\pi}{2}$ — نقطتان.

٣. MVT يضمن واحدة على الأقل؛ هنا اثنتان. ■

- **النتيجة:** $c \in \{\pi/2, 3\pi/2\}$.

- **الربط بالذكاء الاصطناعي:** «دورة كاملة بمتوسط صفري» — الإشارات المتناوبة لا تحمل انحيازاً صافياً، أساس تحليل الضجيج المتعامد في SGD.

مثال (8.6-10).

- **المعطيات:** $f(x) = x^3$ على $[-1, 2]$.
- **المطلوب:** نقطة MVT.
- **الحل:**

١. الميل القاطع $= \frac{8-(-1)}{3} = 3$.

٢. $f'(c) = 3c^2 = 3 \Rightarrow c = \pm 1$.

٣. فقط $c = 1$ داخل الفترة. ■

- **النتيجة:** $c = 1$.

- **الربط بالذكاء الاصطناعي:** دالة «سرج» — MVT يعمل لكن النقطة ليست قاعاً؛ تذكير بعدم مساواة «تدرّج متوسط» بـ «قاع».

مثال (8.6-11).

- **المعطيات:** $f(x) = e^{-x} \sin x$ على $[0, 2\pi]$.
- **المطلوب:** استخدم رول لإثبات وجود c بـ $f'(c) = \cot c$... بل بدقة: ابحث عن نقطة المشتقّ الصفرية المضمونة.
- **الحل:**

١. $f(0) = f(2\pi) = 0$ — فرضيات رول متحققة (متصلة وقابلة للاشتقاق).

٢. $f' = e^{-x}(\cos x - \sin x) = 0 \Rightarrow \tan x = 1 \Rightarrow x = \frac{\pi}{4}, \frac{5\pi}{4}$.

٣. كلتاهما في $(0, 2\pi)$. ■

- **النتيجة:** $c \in \{\pi/4, 5\pi/4\}$.

- **الربط بالذكاء الاصطناعي:** «ذبذبة مُخمّدة» — نقاط سكونها تتقدم دورياً؛ نمط التذبذبات في مسار momentum المكبح.

مثال (8.6-12).

- **المعطيات:** $f(x) = \sqrt{x}$ على $[0, 4]$.

- **المطلوب:** MVT وفحص الاتصال عند 0.

- **الحل:**

١. الميل القاطع $= \frac{2-0}{4} = \frac{1}{2} =:$.

٢. $f'(c) = \frac{1}{2\sqrt{c}} = \frac{1}{2} \Rightarrow c = 1$.

٣. $c = 1 \in (0, 4)$ ✓؛ (عند 0 لا اشتقاق لكن الفرضية على الفترة المفتوحة فقط). ■

- **النتيجة:** $c = 1$.

- **الربط بالذكاء الاصطناعي:** فرضية الاشتقاق على الفترة المفتوحة فقط تسمح بزوايا عند الأطراف — يفسّر نجاح الحسارات ذات الحواف الطرفية.

مثال (8.6-13).

- **المعطيات:** $f(x) = x^{2/3}$ على $[-1, 1]$.

- **المطلوب:** هل توجد نقطة رول؟ $(f(-1) = f(1) = 1)$

- **الحل:**

١. f متصلة على $[-1, 1]$ ✓.

٢. $f' = \frac{2}{3}x^{-1/3}$ غير معرّفة عند 0.

٣. لكن الفرضية تتطلب الاشتقاق على الفترة المفتوحة — يوجد 0 فيها $\Longrightarrow$ رول **لا يُطبَّق**. فعلاً: $f' \neq 0$ في أي مكان معرّف. ■

- **النتيجة:** رول لا يسري؛ لا نقطة بمشتقّ صفري.

- **الربط بالذكاء الاصطناعي:** خسارة «القدرة الثلثية» لها قاع حادّ بلا تدرّج صفري — التدرّج ينتفخ قرب القاع، والوصول إليه يحتاج تقنيات خاصة (proximal).

مثال (14-6.8).

- **المعطيات:** $f(x) = x - \sin x$ على $\mathbb{R}$.
- **المطلوب:** استخدم MVT لإثبات أنّ f تزايدية وأنّ $x = \sin x$ حلّ وحيد.
- **الحل:**

١. $f' = 1 - \cos x \geq 0$، وتساوي 0 عند نقاط معزولة فقط.

٢. MVT: $f(b) - f(a) = f'(c)(b-a) \geq 0$ مع مساواة ممكنة فقط إذا... عملياً f متزايدة تماماً.

٣. $f(0) = 0 \implies$ الحلّ الوحيد $x = 0$. ■

- **النتيجة:** حلّه الوحيد $x = \sin x$ هو 0.

- **الربط بالذكاء الاصطناعي:** «تزايدية صارمة رغم صفارات معزولة» يقابل مساراً تحسينياً لا يرتدّ رغم تدرّجات صفورية لحظية — كفاءة في التقدّم الصافي.

مثال (15-6.8).

- **المعطيات:** خسارة لوجستية لمعاملة واحدة $L(w) = \ln(1 + e^{-w})$ مع وسم $+1$.
- **المطلوب:** L'، L''، وتحليل النقطة الحرجة إن وُجدت.
- **الحل:**

١. $L' = \frac{-e^{-w}}{1+e^{-w}} = -\sigma(-w)$.

٢. $L'' = \sigma(-w)(1 - \sigma(-w)) > 0$ دائماً — محدّبة.

٣. لا نقطة حرجة منتهية؛ الصغرى عند $w \to +\infty$ (حدّية لا بلوغ). ■

- **النتيجة:** محدّبة بلا نقطة حرجة داخلية؛ الصغرى «على اللانهاية».

- **الربط بالذكاء الاصطناعي:** «عصا غير قابلة للفصل خطّياً» تدفع الأوزان إلى ما لا نهاية — لهذا التنظيم L2 ضروري لوجود صغرى منتهية (وجود + معقولية).

خيط الفصل

١. **التعريف (1.8)** هو «حساسية» — كم يتغيّر الخرج لكل تغيّر صغير في المدخل.

٢. **القواعد (3.8)–(5.8)** تحوّل حساسيات مركّبة إلى حواصل ضرب حساسيات بسيطة — وهذا حرفياً الرسم البياني الحسابي (computational graph) الذي يبنيه pytorch.

٣. **قاعدة السلسلة** على شبكة عميقة L طبقة:

$$\frac{\partial L}{\partial a_1} = \frac{\partial L}{\partial a_L} \cdot \prod_{k=2}^{L} \frac{\partial a_k}{\partial a_{k-1}} \tag{12.8}$$

— حاصل ضرب «معاملات تمرير»؛ إن كان كلٌّ منها $< \frac{1}{2}$ انهار المنتج أُسّيّاً (vanishing)، وإن كان كلٌّ منها > 2 انفجر (exploding).

٤. **النقاط الحرجة (6.8)** تفسّر هندسة فضاء الخسارة: آبار، سراج، وهضاب.

٥. **لماذا backprop كفء؟** حساب كل التدرّجات الجزئية لشبكة بعُقد N يحتاج $O(N)$ عملية (مرور عكسي واحد) بدل $O(N^2)$ للفروق المنتهية — هذا هو «اكتشاف «backprop الثوري.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
قاعدة السلسلة (5.8)	الانتشار العكسي (فصل 36) بالكامل
(6.8) $\sigma' = \sigma(1-\sigma)$	تدرّج الطبقة اللوجستية وتلاشيها
المشتقّ الثاني (10.8)	Newton/quasi-Newton و Adam (فصل 40)
رول/MVT (11.8)	براهين تقارب التدرّج وتحليل معدّل التعلم
النقاط الحرجة	نقاط السرج وطرق الهروب منها
$O(N)$ للمرور العكسي	اقتصاديات التدريب الضخم

١. احسب $f'(3)$ من التعريف (1.8) للدالة $f(x) = x^2 - 2x$، ثم بالقواعد، وقارن.

٢. أثبت من التعريف أنّ مشتقّ الثابت صفر، ثم أنّ $(cf)' = cf'$.

٣. وفق التعريف: لماذا لا تكون $f(x) = x|x|$ قابلة للاشتقاق عند 0؟ احسب الميلين الأحاديين. (تلميح: افصل $x \gtrless 0$.)

٤. أوجد f' للدالة $f(x) = x^3 \ln x$ بقاعدة الضرب، وحدّد النقطة التي فيها $f' = 0$.

٥. طبّق السلسلة مرتين: $f(x) = \ln(\sin(e^x))$.

٦. احسب مشتقّ $f(x) = \dfrac{e^x}{1+x^2}$ وقيمة $f'(0)$.

٧. أثبت أنّ $(\cot x)' = -\csc^2 x$ من قاعدة القسمة.

٨. أوجد الميلان الأحاديين لـ $f(x) = \begin{cases} x^2 & x \le 0 \\ \sqrt{x} & x > 0 \end{cases}$ عند 0 واستنتج قابلية الاشتقاق.

٩. اشتقّ ضمنياً: $x^2 + xy + y^2 = 7$ وأوجد y' عند $(1, 2)$.

١٠. اشتقّ ضمنياً: $\cos(xy) = y$ وأوجد y' كدالة في x, y.

١١. أوجد y'' للدالة الضمنية $y^2 = x^3$ (منحنى نصف تكعيبي) عند النقطة $(1, 1)$.

١٢. احسب $f^{(4)}(0)$ للدوال: e^{2x}، $\cos x$، $\frac{1}{1+x}$.

١٣. أثبت برووِل أنّ $x^5 + x - 1$ لها جذر وحيد في $(0, 1)$.

١٤. طبّق MVT على $f(x) = \arctan x$ على $[0, 1]$ وأوجد c.

١٥. استخدم MVT لإثبات: $|\sin a - \sin b| \le |a - b|$ لكل a, b.

١٦. أوجد النقاط الحرجة وتصنيفها للدالة $f(x) = x^3 - 6x^2 + 9x + 1$ (اختبارا الأول والثاني).

١٧. أوجد النقاط الحرجة للدالة $f(x) = \frac{x^2+1}{x}$ على $x > 0$ وصنّفها، واستنتج متباينة AM–GM.

١٨. أثبت أنّ $f(x) = x + \ln x$ تزايدية تماماً على $(0, \infty)$ وأنّ معادلة $x + \ln x = 3$ لها حلّ وحيد، وأقدّره بين عددين متتاليين.

١٩. «مقايضة»: لخسارة $L(\eta) = \frac{a}{\eta} + b\eta$ (η معدّل التعلّم، $a, b > 0$)، أوجد η^* التي تصغّر L وقيمة $L(\eta^*)$، وفسّر النتيجة بلغة «تضارب التحيّز والتباين».

٢٠. تحدٍّ تركيبي: شبكتان من طبقتين لكل منهما، بحيث $\frac{\partial a_2}{\partial a_1} = c$ في كل طبقة. لكل $c \in \{0.1, 0.5, 1, 2, 10\}$ احسب معامل التمرير الكلي عبر 20 طبقة، وصنّف الحالة (تلاشي/ثبات/انفجار)، ثم اربط النتيجة بمعادلة (12.8) وبأسباب ظهور LSTM و ReLU.

- **التعريف (1.8):** المشتقّ = نهاية الميول القاطعة؛ الاشتقاق $\Longrightarrow$ الاتصال (والعكس خطأ).
- **القواعد (3.8)–(5.8):** جمع وضرب وقسمة وسلسلة؛ السلسلة هي «القانون الأم» لكل ما هو عميق.
- **الجدول الأولي:** مشتقّات x^n، الأسّيات، اللوغاريتمات، المثلثيات، والعكسية منها، مع σ' و $\tanh'$ كأدوات تعلّم.
- **الضمني والأعلى (9.8)–(10.8):** اشتقاق المنحنيات المربوطة، ومشتقّات عليا تقيس التقوّس.
- **البنية (11.8):** رول والقيمة الوسطى يربطان المتوسط بالمحلي، ويضمنان نقاطاً بمشتقّ محدّد.
- **الهندسة:** النقاط الحرجة = آبار وقمم وسراج؛ اختبارات الإشارة والقيمة الثانية تصنّفها.

الرمز	المعنى	أين عُرّف
$f'(a)$	المشتقّ عند نقطة	(1.8)
$f'_{\pm}(a)$	الميلان الأحادية	(2.8)
$(fg)'$	قاعدة الضرب	(3.8)
$(f/g)'$	قاعدة القسمة	(4.8)
$(g \circ f)'$	قاعدة السلسلة	(5.8)
σ'	مشتقّ السيجمويد	(6.8)
$f^{(n)}$	المشتقّ n-ي	(10.8)
$\prod \partial a_k/\partial a_{k-1}$	معامل التمرير الكلي	(12.8)

١. I. Newton, (1687). *Mathematica Principia Naturalis Philosophiæ* — أول استخدام منهجي للحدّيات اللحظية (بصياغة هندسية).

٢. W. G. Leibniz, (1684). "Nova Methodus pro Maximis et Minimis" — صياغة $\frac{dy}{dx}$ والقواعد الجبرية.

٣. J.-L. Lagrange, (1797). *Théorie des fonctions analytiques* — صياغة المشتقّ كنهاية ونظرية القيمة الوسطى.

٤. M. Spivak, (2008). *Calculus*, 4th ed., Perish or Publish (الفصول 9–11: المشتقّ، القواعد، القيمة الوسطى — أدقّ المعالجات التعليمية).

٥. J. Stewart, (2015). *Early Transcendentals Calculus*, 8th ed., Cengage (مرجع الجداول والتمارين التطبيقية).

٦. R. Williams, & G. Hinton, D., Rumelhart, (1986). "Learning representations by back-propagating errors". *Nature* 323 — الورقة المؤسِّسة للانتشار العكسي.

٧. A. Courville, & Y. Bengio, I., Goodfellow, (2016). *Deep Learning*, MIT Press (الفصل 6.5: قاعدة السلسلة والرسم البياني الحسابي؛ الفصل 8: نقاط السرج والمحسّنات).

٨. A. Walther, & A. Griewank, (2008). *Evaluating Derivatives*, 2nd ed., SIAM (التفاضل الآلي: الأمامي مقابل العكسي وتكلفة $O(N)$).

التفاضل المصفوفي: اليعقوبية، الهِسّية، وقواعد السلسلة

الهدف من الفصل

ثالث فصول الجزء الثاني. النهايات (7) والمشتقّ القياسي (8) جاهزان؛ الآن نرفع كل شيء إلى عالم المصفوفات — لغة الشبكات العصبية الفعلية. كل معادلة تحديث أوزان في pytorch أو tensorflow هي تطبيق مباشر لقواعد هذا الفصل.

ثلاثة مواقف:

١. **تدرّج الشبكة** ليس عدداً بل **مصفوفة** (أو موتراً): كل معامل لكل وزن لكل طبقة. اليعقوبية هي «كائن التفاضل» الصحيح في هذا العالم.

٢. **الهِسّية** (مصفوفة المشتقّات الثانية) تحكم «شكل الحوض» حول النقطة الحرجة — منها يأتي تحليل التقوّس، وطرق Newton، وشحاذة النقاط السرج.

٣. **softmax** و **LayerNorm** و **attention** كلها دوالّ متجهية→متجهية؛ تدرّجها معروف بالصيغ المصفوفية التي سنبنيها هنا (مثلاً softmax Jacobian الشهير $\operatorname{diag}(s) - ss^{\top}$).

خريطة الفصل

القسم	الموضوع	الأداة
2.9	اليعقوبية: تعريف وبنية	مصفوفة المشتقّات الجزئية
3.9	الهِسّية والتقوّس	مصفوفة ثانية + تحليل طيفي
4.9	قاعدة السلسلة المصفوفية	ضرب اليعقوبيات
5.9	مشتقّات العمليات المصفوفية	أثر/محدّد/نُرم
6.9	التطبيقات: squares least و softmax	حساب تدرّجات حقيقية
7.9	التجميع: المحسّنات كتطبيق	تجميع

التعريف

dir="ltr"> <div

Definition 1.2.9. (Jacobian) For $\mathbf{f} : \mathbb{R}^n \to \mathbb{R}^m$ with components f_i, the matrix Jacobian is: $J \in \mathbb{R}^{m \times n}$

$$J_{ij} = \frac{\partial f_i}{\partial x_j}.$$

$$J_{\mathbf{f}}(\mathbf{x}) = \begin{bmatrix} \dfrac{\partial f_1}{\partial x_1} & \cdots & \dfrac{\partial f_1}{\partial x_n} \\ \vdots & & \vdots \\ \dfrac{\partial f_m}{\partial x_1} & \cdots & \dfrac{\partial f_m}{\partial x_n} \end{bmatrix} \tag{1.9}$$

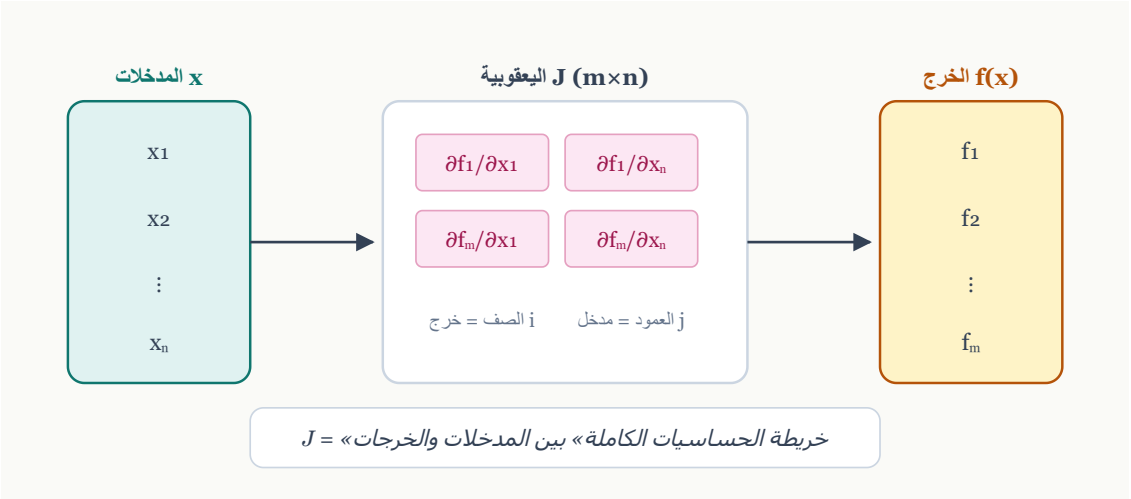
- الصف i = حساسيات الخرج f_i تجاه كل المدخلات.
- التدرّج القياسي $\nabla_x f$ (لمتجه x ودالة سلمية f) هو **متجه صفّ** — حالة خاصة $m = 1$.
- **النظرية 1.2.9:** $\mathbf{f}$ قابلة للاشتقاق (فروبيوس) عند $\mathbf{x}$ $\iff$ اليعقوبية موجودة والحدّ الخطّي الأول يصف التغيّر: $\mathbf{f}(\mathbf{x}+\Delta) = \mathbf{f}(\mathbf{x}) + J\,\Delta + o(\|\Delta\|)$.

جدول الرموز

الرمز	الاسم	المعنى
$J_{\mathbf{f}}$	اليعقوبية	$m \times n$ من الحساسيات
$\nabla_{\mathbf{x}} f$	التدرّج	متجه صف $1 \times n$ $(m = 1)$
$\partial \mathbf{u}/\partial \mathbf{v}$	اليعقوبية المعمّمة	حساسية متجه داخل متجه

رسم توضيحي

<figure> الشكل<figcaption> 1.9: اليعقوبية جدولٌ حسابي — الصف = خرج واحد، العمود = مدخل



شكل ١.٠٩: *
اليعقوبية كحصاد الحساسيات

واحد؛ الخلية J_{ij} = «كم يتغيّر الخرج i إذا تحرّك المدخل j». المحسّنات تقرأ العمود الخاص بالمعامل الذي تريد تحديثه.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الخلط بين اليعقوبية والتدرّج	التدرّج حالة خاصة $(m = 1)$	التدرّج صفّ؛ اليعقوبية $m \times n$
اتجاه اليعقوبية في السلسلة	ضرب J في «الاتجاه الصحيح»	سلسلة الأمامية: $J_{g\circ f} = J_g \cdot J_f$
افتراض تماثل J	التماثل خاصية الهِسّية غالباً	J عامّة غير متماثلة
نسيان الاعتماد على النقطة	$J = J(\mathbf{x})$ — تتغيّر مع كل خطوة	تُحسب في كل تكرار

أمثلة محلولة على اليعقوبية (15 مثالاً)

مثال (9.2-1).

- **المعطيات:** $\mathbf{f}(x_1, x_2) = (x_1^2,\ x_1 x_2)^\top$.
- **المطلوب:** اليعقوبية.
- **الحل:**

١. صفّ الخرج الأول: $(2x_1,\ 0)$.

٢. صفّ الخرج الثاني: $(x_2,\ x_1)$.

٣. $J = \begin{bmatrix} 2x_1 & 0 \\ x_2 & x_1 \end{bmatrix}$. ■

- **النتيجة:** مصفوفة 2×2 تعتمد على النقطة.
- **الربط بالذكاء الاصطناعي:** هذه بنية طبقة خطية مربّعة صغيرة؛ الحساسيات «تتجدد» في كل خطوة — لا مشتقّ واحد يدوم.

مثال (9.2-2).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = A\mathbf{x}$ حيث $A \in \mathbb{R}^{m \times n}$ ثابتة.
- **المطلوب:** اليعقوبية.
- **الحل:**

١. $\frac{\partial f_i}{\partial x_j} = A_{ij} \Longrightarrow f_i = \sum_j A_{ij} x_j$.

٢. $J = A$. ■

- **النتيجة:** يعقوبية التحوّل الخطّي هي المصفوفة نفسها — ثابتة.
- **الربط بالذكاء الاصطناعي:** لطبقة خطية «التدرّج = الأوزان»؛ لذلك تمرير الإشارة عبر الطبقة الخطية يعني الضرب بـ W (أمامياً) أو $W^\top$ (عكسياً).

مثال (9.2-3).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathbf{x}$ (الهوية في $\mathbb{R}^n$).
- **المطلوب:** اليعقوبية.
- **الحل:** $J = I_n$. ■
- **النتيجة:** الهوية $\Longrightarrow$ مصفوفة الوحدة.
- **الربط بالذكاء الاصطناعي:** «تخطّي» (skip/residual) يمرّر الهوية: تدرّجه = الوحدة — السبب الرياضي لنجاح ResNet في إنقاذ التدرّجات.

مثال (9.2-4).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \sigma(A\mathbf{x} + \mathbf{b})$ عنصراً بعنصر (سيجمويد).
- **المطلوب:** اليعقوبية وتبسيطها.
- **الحل:**

١. لكل خرج i: $\frac{\partial f_i}{\partial x_j} = \sigma(z_i)(1 - \sigma(z_i))A_{ij}$ حيث $z = A\mathbf{x} + \mathbf{b}$.

٢. $J = \operatorname{diag}(\sigma(z)(1 - \sigma(z)))\, A$. ■

- **النتيجة:** قطرية × المصفوفة.
- **الربط بالذكاء الاصطناعي:** هذا «سطر backprop للطبقة الكلاسيكية: تدرّج التنشيط (قطري) ثم الأوزان — الانخفاض بمعامل $\leq \frac{1}{4}$ لكل طبقة (تلاشي sigmoid).

مثال (9.2-5).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathrm{ReLU}(\mathbf{x})$ عنصراً بعنصر.
- **المطلوب:** اليعقوبية (شبه-مشتقّ).
- **الحل:**

١. $\frac{\partial f_i}{\partial x_j} = \mathbb{1}[x_i > 0]\, \delta_{ij}$ (مع اختيار فرعي عند 0).

٢. $J = \operatorname{diag}(\mathbf{1}[\mathbf{x} > 0])$ — قطريّة 0/1. ■

- **النتيجة:** قناع ثنائي قطري.
- **الربط بالذكاء الاصطناعي:** backprop عبر ReLU = «مرور عبر الأبواب المفتوحة فقط» — الوحدات الميتة (0 دائماً) تُغلق المسار نهائياً.

مثال (9.2-6).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathbf{x}^\top \mathbf{x}$ (سلمية).
- **المطلوب:** التدرّج $\nabla_{\mathbf{x}}$.
- **الحل:**

١. $\frac{\partial f}{\partial x_i} = 2x_i \Longrightarrow f = \sum_i x_i^2$.

٢. $\nabla_{\mathbf{x}} f = 2\mathbf{x}^\top$ (صفّ). ■

- **النتيجة:** $2\mathbf{x}^\top$.
- **الربط بالذكاء الاصطناعي:** تدرّج أي خسارة تربيعية = ضعف المتجه؛ قاعدة $\frac{1}{2}$ في تعريف MSE ليست ترفاً — لإلغاء 2.

مثال (9.2-7).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathbf{x}^\top A\mathbf{x}$ مع A متماثلة.
- **المطلوب:** التدرّج.
- **الحل:**

١. توسيع: $f = \sum_{i,j} A_{ij}x_i x_j$؛ الاشتقاق الجزئي يعطي $\frac{\partial f}{\partial x_k} = 2\sum_j A_{kj}x_j$.

٢. $\nabla f = 2\,\mathbf{x}^\top A$. ■

- **النتيجة:** $2\mathbf{x}^\top A$ (لـ A متماثلة؛ عامّةً $\mathbf{x}^\top(A + A^\top)$).
- **الربط بالذكاء الاصطناعي:** أشكال الطاقة التربيعية؛ تدرّجها «قوة خطّية» — أساس الأنظمة الديناميكية المستقرة و regularization المربّعة.

مثال (9.2-8).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \begin{pmatrix} e^{x_1}\cos x_2 \\ e^{x_1}\sin x_2 \end{pmatrix}$ (تحويل قطبي).
- **المطلوب:** اليعقوبية ومحدّدها.
- **الحل:**

١. $J = \begin{bmatrix} e^{x_1}\cos x_2 & -e^{x_1}\sin x_2 \\ e^{x_1}\sin x_2 & e^{x_1}\cos x_2 \end{bmatrix}$.

٢. $\det J = e^{2x_1}$ (دائمًا > 0). ■

- **النتيجة:** اليعقوبية = دوران × تمدد؛ المحدّد موجب.
- **الربط بالذكاء الاصطناعي:** «مراوح التدفّق الطبيعي» (normalizing flows) تُبنى من تحويلات يسهل حساب محدّد يعقوبيتها؛ هذا المثال نموذج كامل لذلك.

مثال (9.2-9).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \dfrac{\mathbf{x}}{\|\mathbf{x}\|_2}$ (التطبيع الشعاعي) عند $\mathbf{x} \neq 0$.
- **المطلوب:** اليعقوبية.
- **الحل:**

١. $f_i = x_i r^{-1}$، $r = \|\mathbf{x}\|$.

٢. $\frac{\partial f_i}{\partial x_j} = \frac{\delta_{ij}}{r} - \frac{x_i x_j}{r^3}$.

٣. $J = \frac{1}{r}\left(I - \hat{\mathbf{x}}\hat{\mathbf{x}}^\top\right)$. ■

- **النتيجة:** إسقاط على المستوي العمودي على $\hat{\mathbf{x}}$، مضروباً بـ $\frac{1}{r}$.

- **الربط بالذكاء الاصطناعي:** تطبيع (cosine Embedding similarity) — الحساسية عمودية على الاتجاه؛ لهذا «تحريك الطول» لا يغيّر التشابه الكوسيني.

مثال (9.2-10).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \ln \sum_i e^{x_i} \cdot \mathbf{1}$ (المتجه الثابت ؟(LSE لا — خذ $f(\mathbf{x}) = \log \sum_i e^{x_i}$ سلمية.

- **المطلوب:** التدرّج.

- **الحل:**

١. $\frac{\partial f}{\partial x_k} = \frac{e^{x_k}}{\sum_i e^{x_i}} = \text{softmax}(\mathbf{x})_k$.

٢. $\nabla f = \mathbf{s}^\top$ حيث $\mathbf{s} = \text{softmax}(\mathbf{x})$. ■

- **النتيجة:** تدرّج LSE هو softmax.

- **الربط بالذكاء الاصطناعي:** الازدواجية الجملية LSE–softmax: مشتقّ أحدهما هو الآخر — أساس مرور backprop في softmax-crossentropy (مثال 9.6-3).

مثال (9.2-11).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = A\mathbf{x} - \mathbf{y}$.

- **المطلوب:** اليعقوبية بالنسبة إلى $\mathbf{x}$.

- **الحل:** $J = A$ ($\mathbf{y}$ ثابتة). ■

- **النتيجة:** A.

- **الربط بالذكاء الاصطناعي:** بقايا النموذج الخطّي؛ يعقوبيتها ثابتة — لهذا مشاكل المربعات الصغرى «لطيفة» (تحليلها خطّي بالكامل).

مثال (9.2-12).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = (\mathbf{x}^\top \mathbf{x})\,\mathbf{x}$ (متجه مقياس متجه).

- **المطلوب:** اليعقوبية.

- **الحل:**

١. $f_i = r^2 x_i$؛ $\frac{\partial f_i}{\partial x_j} = 2x_j x_i + r^2 \delta_{ij}$.

٢. $J = r^2 I + 2\mathbf{x}\mathbf{x}^\top$. ■

- **النتيجة:** قطرية + رتبة واحدة.
- **الربط بالذكاء الاصطناعي:** بنية «قياس × بُعد» تظهر في خرائط القياس؛ يعقوبيتها رتبة-واحدة تحتها — طيف قابل للتحليل بقيم ذاتية بسيطة.

مثال (9.2-13).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \begin{pmatrix} x_1 + x_2 \\ x_1 x_2 \end{pmatrix}$.
- **المطلوب:** اليعقوبية ونقاط الشذوذ (يعقوبية شاذّة).
- **الحل:**

١. $J = \begin{bmatrix} 1 & 1 \\ x_2 & x_1 \end{bmatrix}$.

٢. $\det J = x_1 - x_2$؛ يصفُر على الخط $x_1 = x_2$. ■

- **النتيجة:** على ذلك الخط ينهار التحويل (بُعد مفقود).
- **الربط بالذكاء الاصطناعي:** «خطّ شذوذ اليعقوبية» يقابل نقاط انهيار التمييز في شبكات التوليد — حيث تتلاصق الخرائط.

مثال (9.2-14).

- **المعطيات:** $f(\mathbf{x}) = \|\mathbf{x}\|_1 = \sum_i |x_i|$.
- **المطلوب:** التدرّج (subgradient) والنقاط الحرجة.
- **الحل:**

١. لكل $x_i \neq 0$: $\frac{\partial f}{\partial x_i} = \operatorname{sgn}(x_i)$.

٢. عند $x_i = 0$: أيّ قيمة في $[-1, 1]$ صالحة (مجموعة subgradient).

٣. $\nabla = \operatorname{sgn}(\mathbf{x})^\top$ (باستثناء الصفريات). ■

- **النتيجة:** إشارة — بلا قيم قرب الصفر.
- **الربط بالذكاء الاصطناعي:** لاسو (L1): التدرّج لا «يصغر» قرب الصفر — لهذا يضغط الأوزان إلى صفر تماماً (تناثر) بخلاف L2.

مثال (9.2-15).

- **المعطيات:** $\mathbf{f}(\mathbf{x}) = \mathbf{W}\sigma(\mathbf{V}\mathbf{x})$، مقياس مدخل $\mathbf{x} \in \mathbb{R}^n$، σ عنصرية.
- **المطلوب:** اليعقوبية الكاملة بقاعدة السلسلة.
- **الحل:**

١. طبقة داخلية: $\mathbf{z} = \mathbf{V}\mathbf{x}$، $J_z = \mathbf{V}$.

٢. تنشيط: $J_\sigma = \operatorname{diag}(\sigma'(\mathbf{z}))$.

٣. خارجية: $J = \mathbf{W}\operatorname{diag}(\sigma'(\mathbf{z}))\,\mathbf{V}$. ■

- **النتيجة:** حاصل ضرب ثلاث مصفوفات — «شبكة من طبقتين».
- **الربط بالذكاء الاصطناعي:** هذه هي backprop مضغوطة: مرور أمامي يعطي $\mathbf{z}$، ثم اليعقوبية تُبنى من المخرجات المتاحة أصلاً — لا إعادة حساب.

التعريف

dir="ltr"> <div

Definition 9.3.1. (Hessian) For a twice-dffierentiable scalar function $f : \mathbb{R}^n \to \mathbb{R}$:

$$H_{ij} = \frac{\partial^2 f}{\partial x_i \, \partial x_j}.$$

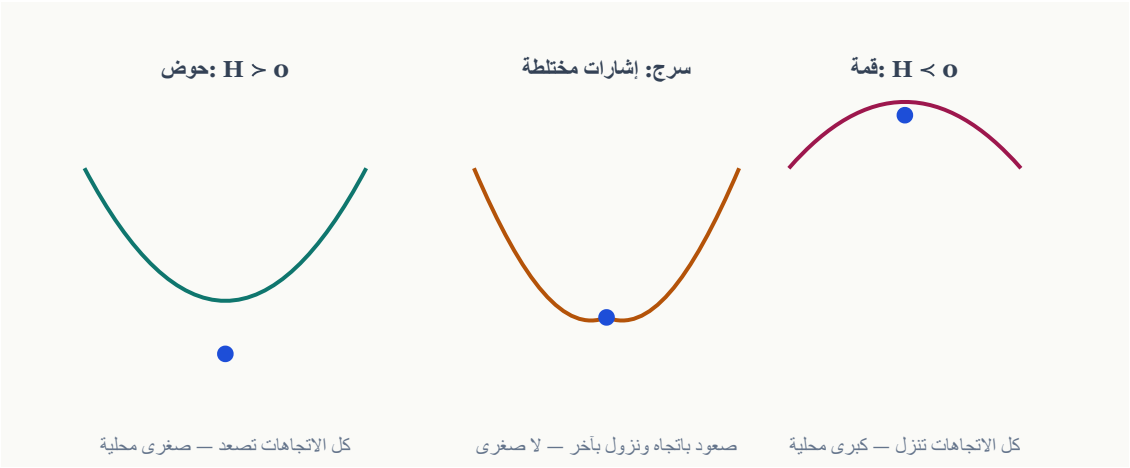
$$H_f(\mathbf{x}) = \nabla^2 f = \begin{bmatrix} \dfrac{\partial^2 f}{\partial x_1^2} & \cdots & \dfrac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & & \vdots \\ \dfrac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \dfrac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \tag{2.9}$$

النظرية 9.3.1 (تماثل شوارتز). إذا كانت المشتقّات الثانية متصلة فإنّ H **متماثلة**: $H_{ij} = H_{ji}$ — ويتبع عندها التحليل الطيفي (فصل 4).

النظرية 9.3.2 (التقوّس والهِسّية). f محدّبة على مجموعة محدّبة مفتوحة $\iff H \succeq 0$ (شبه موجبة) في كل نقطة؛ ومحدّبة تماماً إذا كانت $H \succ 0$.

النظرية 9.3.3 (الشكل الثاني يصنّف النقطة الحرجة). عند نقطة $\nabla f = 0$:

- $H \succ 0 \implies$ صغرى محلية (حوض).
- $H \prec 0 \implies$ كبرى محلية (قمة).
- إشارات مختلطة $\implies$ **نقطة سرج**.
- H شبه موجبة مفردة $\implies$ غير حاسمة (تحتاج فحصاً أعلى).



شكل ٢.٩: *
الهِسّية تصنّف النقطة الحرجة

رسم توضيحي

<figure> الشكل<figcaption> 2.9: الهِسّية كـ«عدسة تقوّس» — في الحوض كل الاتجاهات تصعد ($H \succ 0$)؛ في السرج تصعد بعض الاتجاهات وتنزل أخرى (H بإشارات مختلطة)؛ على القمة تنزل كل الاتجاهات ($H \prec 0$).</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«H موجبة عند نقطة حرجة $\Rightarrow$ صغرى **عالمية**»	فقط محلية؛ الشمولية تحتاج محدّبة	محدّبة $f + 0 \succeq H \Rightarrow$ عالمية
«$\nabla f = 0$ و $H \succeq 0 \Rightarrow$ صغرى»	في الحقيقة يحتاج حذراً: $x^4 + y^4$ عند x^3 0...	$H \succ 0$ هي الشرط الحاسم؛ $\succeq 0$ بلا فحص إضافي
نسيان التماثل قبل التحييد الطيفي	التحليل يفترض متماثلة	استخدم $\frac{H+H^\top}{2}$ عددياً
حساب H لشبكة ضخمة	معاملات $O(n^2)$	بدائل: تقديرات (Adam)، منتجات Hessian-vector

أمثلة محلولة على الهِسّية والتقوّس (15 مثالاً)

مثال (3.9-1).

- **المعطيات:** $f(x, y) = x^2 + 4y^2$.
- **المطلوب:** الهِسّية والتصنيف عند النقطة الحرجة.
- **الحل:**

١. $\nabla f = (2x, 8y) \Rightarrow$ نقطة حرجة وحيدة $(0, 0)$.

٢. $H = \begin{bmatrix} 2 & 0 \\ 0 & 8 \end{bmatrix} \succ 0$.

٣. صغرى محلية (وعالمية — محدّبة). ■

- **النتيجة:** صغرى عند الأصل.

• **الربط بالذكاء الاصطناعي:** «حوض مُستطيل»: القيم الذاتية $2, 8$ تحكم سرعة النزول بكل اتجاه، الاختلاف 4× يبطئ الاتجاه الضيق — فكرة conditioning التي عالجناها بالضبط المسبق.

مثال (9.3-2).

• **المعطيات:** $f(x, y) = x^2 - y^2$.

• **المطلوب:** الهِسّية والتصنيف.

• **الحل:**

١. $H = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$: قيم ذاتية ± 2 مختلطة.

٢. النقطة الحرجة $(0, 0)$ نقطة **سرج**. ■

• **النتيجة:** سرج — لا صغرى ولا كبرى.

• **الربط بالذكاء الاصطناعي:** النقاط السرجية هي «القاع» الفعلي للشبكات الكبيرة (ليس الحد الأدنى المحلي المنفرد)؛ أساس السؤال «لماذا تصل SGD إلى سراج؟» — والجواب في أبعاد عالية أصبحت قاعاً بنيوياً.

مثال (9.3-3).

• **المعطيات:** $f(x, y) = x^4 + y^4 - 4xy$.

• **المطلوب:** النقاط الحرجة وتصنيفها.

• **الحل:**

١. $\nabla = (4x^3 - 4y,\ 4y^3 - 4x) = 0 \implies y = x^3$ و $x = y^3 \implies x = x^9 \implies x \in \{0, \pm 1\}$.

٢. $H = \begin{bmatrix} 12x^2 & -4 \\ -4 & 12y^2 \end{bmatrix}$.

٣. عند $(0, 0)$: $\det = -16 < 0$ سرج؛ عند $(1, 1)$ و $(-1, -1)$: $\det = 128 > 0$ و $H_{11} > 0 \implies$ صغران. ■

• **النتيجة:** سرج مركزي وقاعان متناظران.

• **الربط بالذكاء الاصطناعي:** هندسة «سرج يفصل قاعين» في مسائل التماثل (وزن إيجابي أم سلبي؟) — كسر التماثل عشوائياً يختار قاعاً.

مثال (9.3-4).

• **المعطيات:** $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top A\mathbf{x} - \mathbf{b}^\top\mathbf{x}$ مع $A \succ 0$.

- **المطلوب:** التدرّج والهِسّية والحل الأمثل.
- **الحل:**

١. $\nabla f = A\mathbf{x} - \mathbf{b}$؛ $H = A$.

٢. الحل: $A\mathbf{x} = \mathbf{b} \implies \mathbf{x}^* = A^{-1}\mathbf{b}$.

٣. محدّبة تماماً $\implies$ الصغرى وحيدة وعالمية. ■

- **النتيجة:** $\mathbf{x}^* = A^{-1}\mathbf{b}$.

- **الربط بالذكاء الاصطناعي:** هذه «المشكلة التربيعية الأم» — خسارة الانحدار الخطّي بحلّها المغلق (المعادلات الطبيعية) وقاعدتها لمحسّنات Newton وطريقة المقارنة المثالية (polynomial conditioning) من فصل 6).

مثال (9.3-5).

- **المعطيات:** $f(x, y) = e^{x+y}$.
- **المطلوب:** الهِسّية والتقوّس.
- **الحل:**

١. كل المشتقّات الثانية $= e^{x+y}$.

٢. $H = e^{x+y}\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \succeq 0$ (مفردة).

٣. محدّبة (غير تماماً) في كل $\mathbb{R}^2$. ■

- **النتيجة:** محدّبة بلا حوض مغلق — «مستوٍ مائل» في اتجاه $(1, 1)$.

- **الربط بالذكاء الاصطناعي:** خسارة أُسّية غير مقيدة؛ لذلك نأخذ لوغاريتمها قبل التحسين (log-space) لتحويلها إلى مشكلة خطّية.

مثال (9.3-6).

- **المعطيات:** $f(x, y) = \ln(x^2 + y^2 + 1)$.
- **المطلوب:** الهِسّية والتصنيف عند الأصل.
- **الحل:**

١. $\nabla f = \frac{2(x,y)}{r^2+1}$؛ الأصل نقطة حرجة.

٢. بعد الحساب: $H_{ij} = 2\left(\frac{\delta_{ij}}{r^2+1} - \frac{2x_i x_j}{(r^2+1)^2}\right)$.

٣. عند الأصل: $H = 2I \succ 0 \implies$ صغرى. وعالمياً ($f(0) = 0 \leq f$). ■

- **النتيجة:** صغرى عالمية عند الأصل بقيمة 0.

- **الربط بالذكاء الاصطناعي:** «لوغاريتم نُرم مربّعة + 1» — شكل LayerNorm التربيعي؛ مقعّر مركزياً وسلس — أخف من مربّع خالص.

مثال (9.3-7).

- **المعطيات:** $f(x, y) = x^3$.
- **المطلوب:** الهِسّية وتحليل $(0, 0)$.
- **الحل:**

١. $H = \begin{bmatrix} 6x & 0 \\ 0 & 0 \end{bmatrix}$؛ عند الأصل $H = 0$.

٢. الاختبار الثاني محايد.

٣. التحليل المباشر: x^3 سالبة لجانب وموجبة لآخر $\implies$ لا صغرى. ■

- **النتيجة:** $H = 0$ لا تكفي؛ الشكل الثالث (الدرجة الفردية) حاسم.

- **الربط بالذكاء الاصطناعي:** «هضاب فردية الدرجة» تُغشّ الاختبار الثاني؛ أدوات الذيل الأعلى (ثوابت شريطية) لازمة في تحليل أدقّ للمساحات المسطّحة.

مثال (9.3-8).

- **المعطيات:** $f(\mathbf{x}) = \|\mathbf{x}\|_2^2$.
- **المطلوب:** الهِسّية.
- **الحل:** $H = 2I$ (مثال 9.2-6 مرتين). ■
- **النتيجة:** $2I$ — أكثف محدّب ممكن (قيم ذاتية متساوية).

- **الربط بالذكاء الاصطناعي:** «لا تحيّز اتجاهي»: قيم ذاتية متساوية تعني تساوي مقاومة كل الاتجاهات — لهذا regularization المربّع هو «الأدنى تفضيلاً» بين العقوبات السهلة التحليل.

مثال (9.3-9).

- **المعطيات:** $f(x, y) = \frac{x^2}{a^2} + \frac{y^2}{b^2}$.

- **المطلوب:** الهِسّية والقيم الذاتية و«الـ conditioning».
- **الحل:**

١. $H = \operatorname{diag}\left(\frac{2}{a^2}, \frac{2}{b^2}\right)$.

٢. القيم الذاتية كما هي؛ $\kappa = \frac{b^2}{a^2}$ (بافتراض $b > a$).

٣. κ كبير $\Longrightarrow$ «وادٍ ضيّق» — بطء Descent nesterov/Gradient مع معدّل واحد. ■

- **النتيجة:** conditioning $= b^2/a^2$.

- **الربط بالذكاء الاصطناعي:** جسر مباشر إلى فصل 6: عدد الشرط المصفوفي يفسّر أسبوعيات التدريب البطيئة؛ Adam يعادل فعلياً القيم الذاتية (تحديد مسبق عنيف).

مثال (3.9-10).

- **المعطيات:** $f(x, y) = xy$.
- **المطلوب:** الهِسّية والنقطة الحرجة.
- **الحل:**

١. $\nabla = (y, x)$؛ الحرجة $(0, 0)$.

٢. $H = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$؛ قيم ذاتية ± 1.

٣. سرج. ■

- **النتيجة:** سرج بحِسّية متساوية ومتعاكسة.

- **الربط بالذكاء الاصطناعي:** «ضرب متغيرين» نموذج سرج — نفس بنية $w_1 w_2$ في دوالّ الخسارة غير المحدّبة البسيطة؛ لاحظ أنّ $|xy|$ له قاع «خطّي».

مثال (3.9-11).

- **المعطيات:** $f(x, y) = x^4 + y^2 - 2x^2$.
- **المطلوب:** نقاط حرجة وتصنيفها.
- **الحل:**

١. $\nabla = (4x^3 - 4x,\ 2y) = (0, 0) \Longrightarrow y = 0,\ x \in \{0, \pm 1\}$.

٢. $H = \operatorname{diag}(12x^2 - 4,\ 2)$.

٣. عند $(0, 0)$: $H_{11} = -4$ سرج؛ عند $(\pm 1, 0)$: $H_{11} = 8 > 0$ صغران بقيمة -1. ■

- **النتيجة:** قاعان عند $x = \pm 1$، سرج عند الأصل.

- **الربط بالذكاء الاصطناعي:** «وادي مزدوج بسرج وسطي» — التماثل بين القاعين (للاطّلاع: f زوجية) يجعل الأصل نقطة غير مستقرة؛ عشوائية التهيئة تُخرج المسار من السرج.

مثال (9.3-12).

- **المعطيات:** $f(x,y) = x^2 y^2$.
- **المطلوب:** النقاط الحرجة والتصنيف (حذر: H صفري على المحاور).
- **الحل:**

١. $\nabla = (2xy^2, 2x^2y) = (0,0)$ على المحورين كلهما — خط حرج.

٢. $H = \begin{bmatrix} 2y^2 & 4xy \\ 4xy & 2x^2 \end{bmatrix}$، على المحاور H لها صفر قيم ذاتية.

٣. $f \geq 0$ دائماً و $f = 0$ على المحورين $\Longrightarrow$ صغرى (عالمية) على الخطّين. ■

- **النتيجة:** صغرى عالمية على المحورين؛ غير «معزولة».

- **الربط بالذكاء الاصطناعي:** «حدّ أدنى على منحنى» — انعكاس شائع للشبكات الفائقة التعدّد: مجموعة حلول لا نقطة؛ لهذا نضيف تنظيم $+\lambda\|w\|^2$ لاختيار حلّ معيّن (الأصغر نُرماً).

مثال (9.3-13).

- **المعطيات:** $f(x,y) = x\ln(x) + y\ln(y)$ (إنتروبيا سلبية) على $x, y > 0$.
- **المطلوب:** الهِسّية والتقوّس.
- **الحل:**

١. $H = \operatorname{diag}\left(\frac{1}{x}, \frac{1}{y}\right) \succ 0$.

٢. محدّبة تماماً على الربع الموجب. ■

- **النتيجة:** محدّبة تماماً.

- **الربط بالذكاء الاصطناعي:** «الإنتروبيا مقعّرة» $\Longrightarrow$ الإنتروبيا السلبية محدّبة — هذا يضمن أنّ أغراض الاستفادة القصوى (تعظيم الإنتروبيا) مسائل محدّبة سهلة الحل (max-ent).

مثال (9.3-14).

- **المعطيات:** $f(x,y) = \frac{1}{2}\|\mathbf{a}^\top \mathbf{x} - y\|^2$ (عنصر انحدار واحد).
- **المطلوب:** الهِسّية.
- **الحل:**

١. $\nabla = (\mathbf{a}^\top \mathbf{x} - y)\,\mathbf{a}^\top$.

٢. $H = \mathbf{a}\mathbf{a}^\top$ (رتبة 1).

٣. شبه موجبة $\Rightarrow$ محدّبة، لكن مفردة (بُعد بلا تقوّس على العمودي على $\mathbf{a}$). ■

- **النتيجة:** $H = \mathbf{a}\mathbf{a}^\top$ — رتبة 1.
- **الربط بالذكاء الاصطناعي:** «تقوّس عيّنة واحدة» رتبة-1؛ مكدّس على n عيّنات يعطي $H = \sum \mathbf{a}_i\mathbf{a}_i^\top = X^\top X$ — مصفوفة الغرام المعروفة.

مثال (3.9-15).

- **المعطيات:** $L(\mathbf{w}) = -\sum_i [y_i \ln \hat{y}_i + (1-y_i)\ln(1-\hat{y}_i)]$ للوجستية بمعامل واحد $\hat{y} = \sigma(wx)$.
- **المطلوب:** L'' على السلم، ثم الهِسّية لمعامل متعدّد.
- **الحل:**

١. $L' = (\hat{y} - y)x$، $L'' = \hat{y}(1-\hat{y})x^2 \geq 0$.

٢. متعدّد: $H = X^\top \mathrm{diag}(\hat{y}_i(1-\hat{y}_i))X \succeq 0$.

٣. الخسارة اللوجستية محدّبة في المعاملات. ■

- **النتيجة:** $H = X^\top D X$ — «غرام موزون».

- **الربط بالذكاء الاصطناعي:** هذه هي حجة «لماذا يعمل الانحدار اللوجستي بمحسّن بسيط»: محدّبة، هِسّية موجبة نصفياً، والوزن D يشبه «تشويش برنولي» — كل أدوات التقوّس هنا من هذا الفصل.

النظرية

dir="ltr"> <div

Chain rule, (matrix form). For $\mathbf{x} \xrightarrow{f} \mathbf{u} \xrightarrow{g} \mathbf{y}$ with compatible dimensions:

$$J_{g\circ f}(\mathbf{x}) = J_g(\mathbf{f}(\mathbf{x}))\cdot J_f(\mathbf{x}).$$

$$J_{g\circ f} = J_g\, J_f \tag{3.9}$$

الصيغ الجاهزة الأكثر استخداماً (سلمية L، متجهات):

التركيب	التدرّج $\nabla_{\mathbf{x}} L$
$L = f(\mathbf{u})$، $\mathbf{u} = A\mathbf{x}$	$A^\top \nabla_{\mathbf{u}} f$
$L = f(\mathbf{u})$، $\mathbf{u} = g(\mathbf{x})$ عنصرية	$\nabla_{\mathbf{u}} f \odot g'(\mathbf{x})$
$L = \|\mathbf{u}\|^2$، $\mathbf{u} = A\mathbf{x} - \mathbf{b}$	$2A^\top(A\mathbf{x} - \mathbf{b})$

$$\nabla_{\mathbf{x}} \big\|A\mathbf{x} - \mathbf{b}\big\|^2 = 2A^\top(A\mathbf{x} - \mathbf{b}) \tag{4.9}$$

برهان (4.9)

١. $J_u = A \implies \mathbf{u} = A\mathbf{x} - \mathbf{b}$ (مثال 9.2-11).

٢. $\nabla_u \|\mathbf{u}\|^2 = 2\mathbf{u}^\top$.

٣. السلسلة: $2\mathbf{u}^\top A = 2A^\top(A\mathbf{x} - \mathbf{b})$. ■

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
$J_{g\circ f} = J_f J_g$	ترتيب معكوس؛ الأبعاد لا تطابق	«الخارجي أولاً»: $J_g J_f$
نسيان النقل $A^\top$ عند الرجوع	«مرور أمامي بـ A، عكسي بـ $A^\top$»	القاعدة الذهبية
استخدام $J^\top$ عوضاً عن ∇ في السلم	السلم صفّ؛ J عمودي في بعض النصوص	ثبّت اصطلاحاً واحداً في كل الفصل
ضرب قطرية بعمود بترتيب خاطئ	$\mathrm{diag}(v)\mathbf{u} = \mathbf{u} \odot \mathbf{v}$	الضرب العنصري اختزال للقطرية

أمثلة محلولة على السلسلة المصفوفية (15 مثالاً)

مثال (4.9-1).

- **المعطيات:** $L = \|\mathbf{u}\|^2$، $\mathbf{u} = A\mathbf{x}$، $A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$، $\mathbf{x} = (1, 1)^\top$.
- **المطلوب:** $\nabla_{\mathbf{x}} L$ بـ (4.9).
- **الحل:**

١. $\mathbf{u} = (3, 1)$؛ $\|\mathbf{u}\|^2 = 10$.

٢. $2A^\top \mathbf{u} = 2\begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}\begin{pmatrix} 3 \\ 1 \end{pmatrix} = (6, 14)^\top$. ■

- **النتيجة:** $(6, 14)^\top$.
- **الربط بالذكاء الاصطناعي:** هذه «خطوة SGD في انحدار ريدج بوجه أوزان عام؛ لاحظ النقل — النسيان خطأ التنفيذ الأول في backprop اليدوي.

مثال (4.9-2).

- **المعطيات:** $L = \mathbf{c}^\top \mathbf{u}$، $\mathbf{u} = g(\mathbf{x})$ عنصرية.
- **المطلوب:** $\nabla_{\mathbf{x}} L$.
- **الحل:**

١. $J_u = \mathrm{diag}(g'(\mathbf{x}))$.

٢. $\nabla = \mathbf{c}^\top \mathrm{diag}(g') = (\mathbf{c} \odot g'(\mathbf{x}))^\top$. ■

- **النتيجة:** ضرب عنصري.
- **الربط بالذكاء الاصطناعي:** طبقة خطية «مقنّعة» بوزن ثابت $\mathbf{c}$؛ الضرب العنصري هو أرخص عمليات الـ backprop — $O(n)$.

مثال (9.4-3).

- **المعطيات:** شبكتان خطيتان متتاليتان: $\mathbf{u} = V\mathbf{x}$، $\mathbf{y} = W\mathbf{u}$، خسارة $\|\mathbf{y} - \mathbf{t}\|^2$.
- **المطلوب:** التدرّجين ∇_W و ∇_V (تجميع).
- **الحل:**

١. $\mathbf{r} = WV\mathbf{x} - \mathbf{t}$ (بقايا).

٢. $\nabla_W = 2\mathbf{r}(V\mathbf{x})^\top$.

٣. $\nabla_V = 2W^\top \mathbf{r}\,\mathbf{x}^\top$. ■

- **النتيجة:** «خطأ × مدخل الطبقة» لكل طبقة.
- **الربط بالذكاء الاصطناعي:** هذا backprop عملي بمعادلتين: كل تحديث يلزمه فقط البقايا ومدخل الطبقة — مبدأ «إعادة استخدام الوسطيات» الذي يجعل التدريب ممكناً.

مثال (9.4-4).

- **المعطيات:** $\mathbf{u} = \sigma(V\mathbf{x})$ (سيجمويد عنصري)، ثم $\mathbf{y} = W\mathbf{u}$، و $L = \|\mathbf{y} - \mathbf{t}\|^2$.
- **المطلوب:** ∇_V الكامل.
- **الحل:**

١. بقايا الطبقة الوسطى: $\boldsymbol{\delta} = 2W^\top(\mathbf{y} - \mathbf{t})$.

٢. مضاعفة بالتدرّج المحلي: $\boldsymbol{\delta} \odot \sigma'(\mathbf{z})$ حيث $\mathbf{z} = V\mathbf{x}$، و $\sigma' = \sigma(1 - \sigma)$.

٣. $\nabla_V = (\boldsymbol{\delta} \odot \sigma'(\mathbf{z}))\,\mathbf{x}^\top$. ■

- **النتيجة:** «خطأ راجع × تدرّج تنشيط × مدخل».
- **الربط بالذكاء الاصطناعي:** هذه هي الصيغة المتعلمة في كل كتب الشبكات؛ عامل $\sigma' \le \frac{1}{4}$ هو مصدر التلاشي المذكور سابقاً.

مثال (9.4-5).

- **المعطيات:** $L = \frac{1}{2}\|A\mathbf{x} - \mathbf{b}\|^2$ مع $\frac{1}{2}$.
- **المطلوب:** التدرّج وحلّ الصفر.
- **الحل:**

١. $\nabla = A^\top(A\mathbf{x} - \mathbf{b})$ (النصف ألغى الـ 2).

٢. الصفر: المعادلات الطبيعية $A^\top A\mathbf{x} = A^\top\mathbf{b}$.

٣. إن كانت A رتبة كاملة: $\mathbf{x}^* = (A^\top A)^{-1}A^\top\mathbf{b}$. ■

- **النتيجة:** حلّ المربعات الصغرى.

- **الربط بالذكاء الاصطناعي:** $A^\top A$ ظهرت في فصل 6 بحساب شرطها κ^2 — هنا نرى من أين تأتي أصلاً: من تربيع الخسارة.

مثال (٩.٤-6).

- **المعطيات:** $L = \operatorname{tr}(X^\top XW)$.
- **المطلوب:** ∇_W.
- **الحل:**

١. $\operatorname{tr}(X^\top XW) = \operatorname{tr}(WX^\top X)$ (دورية الأثر).

٢. بالتمايز: $\nabla_W = X^\top X$. ■

- **النتيجة:** $X^\top X$ — مصفوفة الغرام.

- **الربط بالذكاء الاصطناعي:** مصفوفة الغرام أساس «تناسق الأسلوب» في transfer style neural (غرام الأنماط) و PCA (التباين المشترك).

مثال (٩.٤-7).

- **المعطيات:** $L = \operatorname{tr}(AX)$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $\operatorname{tr}(AX) = \sum_{i,j} A_{ji}X_{ij}$.

٢. $\nabla_X = A^\top$. ■

- **النتيجة:** النقل فقط.

- **الربط بالذكاء الاصطناعي:** «مشتقّ الأثر هو النقل» — قاعدة أثرية أولى تُبنى عليها كل القواعد المصفوفية السريعة في الأوراق.

مثال (٩.٤-8).

- **المعطيات:** $L = \ln\det X$ (X موجبة التعريف).
- **المطلوب:** ∇_X.
- **الحل:**

١. $d(\ln\det X) = \operatorname{tr}(X^{-1}dX)$.

٢. $\nabla_X = X^{-1}$ (بالتماثل). ■

- **النتيجة:** X^{-1}.

- **الربط بالذكاء الاصطناعي:** «log-det» «barrier» في الأمثلية الداخلية و GPs: عقوبة على انكماش التباينات — تدرّجها هو المعكوس نفسه.

مثال (9-4.9).

- **المعطيات:** $L = \mathbf{x}^\top A\mathbf{x}$ عامّة (غير متماثلة).
- **المطلوب:** ∇ وإشكالية الجزء المضاد للتماثل.
- **الحل:**

١. $\nabla = \mathbf{x}^\top(A + A^\top)$.

٢. الجزء المضاد للتماثل يختفي (لأنّ $\mathbf{x}^\top M\mathbf{x} = 0$ لـ M مضادة للتماثل).

٣. عملياً نستبدل A بجزئها المتماثل. ■

- **النتيجة:** التدرّج «يرى» الجزء المتماثل فقط.

- **الربط بالذكاء الاصطناعي:** مصفوفات أوزان غير متكافئة الشكل؛ التدرّجات تقيس أثر الجزء المتماثل — معلومة توفّر حسابات زائدة.

مثال (10-4.9).

- **المعطيات:** $L = \|\mathbf{u}\|_2$، $\mathbf{u} \neq 0$، $\mathbf{u} = g(\mathbf{x})$.
- **المطلوب:** $\nabla_{\mathbf{x}} L$ وتحليلها عند $\mathbf{u} \to 0$.
- **الحل:**

١. $\nabla_u = \frac{\mathbf{u}^\top}{\|\mathbf{u}\|}$.

٢. بالسلسلة: $\frac{\mathbf{u}^\top}{\|\mathbf{u}\|} J_g$.

٣. عند $\mathbf{u} = 0$: غير قابلة للاشتقاق (شوكة). ■

- **النتيجة:** اتجاه الوحدة — بلا معامل طول.

- **الربط بالذكاء الاصطناعي:** لماذا نستخدم $\|u\|_2^2 + \epsilon$ بدل $\|u\|_2$ في الخسارات: نعومن الشوكة عند الصفر (نفس حجة الجذر في فصل 7).

مثال (9.4-11).

- **المعطيات:** $L = (\mathbf{w}^\top \mathbf{x}_i - y_i)^2$ لعيّنة واحدة، ثم المجموع على العيّنات.
- **المطلوب:** التدرّج الكلي.
- **الحل:**

١. عيّنة: $2(\mathbf{w}^\top \mathbf{x}_i - y_i)\mathbf{x}_i^\top$.

٢. المجموع: $2X^\top(X\mathbf{w} - \mathbf{y})$ حيث صفوف X هي $\mathbf{x}_i^\top$. ■

- **النتيجة:** $2X^\top(X\mathbf{w} - \mathbf{y})$.
- **الربط بالذكاء الاصطناعي:** «جمع التدرّجات عبر العيّنات = مصفوفة البيانات» — gradient batch يكتب بهذا السطر الواحد.

مثال (9.4-12).

- **المعطيات:** $L = \frac{1}{2}\|\mathbf{w}\|^2 + \lambda \max(0, 1 - y\,\mathbf{w}^\top \mathbf{x})$ (خسارة مفصلية SVM بعينة).
- **المطلوب:** subgradient.
- **الحل:**

١. إن $y\mathbf{w}^\top \mathbf{x} \geq 1$: $\nabla = \mathbf{w}^\top$.

٢. إن $y\mathbf{w}^\top \mathbf{x} < 1$: $\mathbf{w}^\top - \lambda y \mathbf{x}^\top$.

٣. الحدّية: مجموعة كاملة بين الاثنين. ■

- **النتيجة:** $\mathbf{w}^\top - \lambda y \mathbf{x}^\top \mathbb{1}[y\mathbf{w}^\top \mathbf{x} < 1]$.
- **الربط بالذكاء الاصطناعي:** SVM بـ Pegasos: تدرّج يُصحّح فقط «الانتهاكات» — نفس منطق ReLU: أبواب تفتح عند الحاجة.

مثال (9.4-13).

- **المعطيات:** $L = \text{softmax}(\mathbf{z})_k$، $\mathbf{z} = W\mathbf{x}$.
- **المطلوب:** ∇_W لخرج واحد.
- **الحل:**

١. $\nabla_z L = s \odot (\mathbf{e}_k - s)$ (مثال 9.6-3).

٢. بالسلسلة: $\nabla_W = (s \odot (\mathbf{e}_k - s))\,\mathbf{x}^\top$. ■

- **النتيجة:** «إشارة خطأ مصنّف × مدخل».
- **الربط بالذكاء الاصطناعي:** تصنيف الأحرف/الأصناف بطبقة softmax خطية: تحديث الصف k يتناسب مع «الفرق بين الحقيقة والتوقّع».

مثال (9.4-14).

- **المعطيات:** تدفّق عميق: $\mathbf{a}_{k+1} = \phi(W_k\mathbf{a}_k + \mathbf{b}_k)$، $k = 1..K$، خسارة $L(\mathbf{a}_{K+1})$.
- **المطلوب:** صيغة الانتشار العكسي الكاملة.
- **الحل:**

١. عرّف إشارة الطبقة $\boldsymbol{\delta}_k = \frac{\partial L}{\partial \mathbf{z}_k}$ حيث $\mathbf{z}_k = W_k\mathbf{a}_k + \mathbf{b}_k$.

٢. الاستقرار الخلفي: $\boldsymbol{\delta}_k = W_{k+1}^{\top}\boldsymbol{\delta}_{k+1} \odot \phi'(\mathbf{z}_k)$.

٣. التدرّجات: $\nabla_{W_k} = \boldsymbol{\delta}_k\mathbf{a}_k^{\top}$، $\nabla_{\mathbf{b}_k} = \boldsymbol{\delta}_k$. ■

- **النتيجة:** ثلاث معادلات تُشغّل كل التعلم العميق.
- **الربط بالذكاء الاصطناعي:** هذه هي المعادلات التي تنفّذها autograd؛ كل شيء في الفصلين 7–9 كان تمهيداً لها.

مثال (9.4-15).

- **المعطيات:** $L = \|A\mathbf{x} - \mathbf{b}\|_1$ (خسارة Huber خامسية — L1 للأخطاء).
- **المطلوب:** subgradient بالسلسلة المصفوفية.
- **الحل:**

١. $\nabla_u\|\mathbf{u}\|_1 = \operatorname{sgn}(\mathbf{u})$ (عنصرياً، عند الأصفار $[-1, 1]$).

٢. $\nabla_{\mathbf{x}} = \operatorname{sgn}(A\mathbf{x} - \mathbf{b})^{\top}A$. ■

- **النتيجة:** إشارة البقايا × مصفوفة التصميم.
- **الربط بالذكاء الاصطناعي:** LAD-regression (أقل انحراف مطلق) — متين للقيم الشاذة؛ التنفيذ يستخدم median/quantile أو smooth approximation (Huber).

قواعد الأثر والتفاضل

$f(X)$ الدالة	$\nabla_X f$	الشرط
$\operatorname{tr}(X)$	I	—
$\operatorname{tr}(AX)$	$A^{\top}$	—
$\operatorname{tr}(X^{\top}AX)$	$(A + A^{\top})X$	—
$\ln\det X$	X^{-1}	$X \succ 0$
$\det X$	$\det(X)\,X^{-1}$	X قابلة للعكس
$\operatorname{tr}(X^{-1}A)$	$-X^{-1}A^{\top}X^{-1}$	—

$$\nabla_X \ln\det X = X^{-1}, \qquad \nabla_X \det X = \det(X)\,X^{-1} \tag{5.9}$$

برهان نموذجي — $\ln\det$:

للمقاربة $X \to X + \epsilon E$:

$$\ln\det(X+\epsilon E) = \ln\det X + \ln\det(I + \epsilon X^{-1}E) = \ln\det X + \epsilon\,\mathrm{tr}(X^{-1}E) + O(\epsilon^2),$$

فالمشتقّ الاتجاهي في E هو $\mathrm{tr}(X^{-1}E)$، ومنه (5.9). ■

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
$\nabla \mathrm{tr}(AX) = A$	نسيان النقل بالاصطلاح	$A^\top$ (باصطلاح التدرّج الصفّي)
نسيان شرط موجبة التعريف في $\ln\det$	اللوغاريتم غير معرّف للمحدّد السالب	قيّد $X \succ 0$
مشتقّ $\det$ للأبعاد الكبيرة كـ «حساسية محدّد» خطّية	غير خطيّ تماماً	(5.9) — معكوس × محدّد
الخلط بين $d\,\mathrm{tr}$ و $d(\cdot)$ المقطري	التفاضل المصفوفي يخضع لدورة الأثر	اكتب $df = \mathrm{tr}(G^\top dX)$ ثم استخرج G

أمثلة محلولة على مشتقّات العمليات المصفوفية (15 مثالاً)

مثال (5.9-1).

- **المعطيات:** $f(X) = \mathrm{tr}(X)$ لـ $X \in \mathbb{R}^{n\times n}$.
- **المطلوب:** $\nabla_X f$.
- **الحل:**

١. $df = \sum_i dX_{ii} = \mathrm{tr}(I\,dX)$.

٢. $\nabla = I$. ■

- **النتيجة:** I.
- **الربط بالذكاء الاصطناعي:** «الأثر» يجمع القطريات؛ تدرّجه موحّد — أساس متابعة «حجم إجمالي» في مقياسات المصفوفات.

مثال (5.9-2).

- **المعطيات:** $f(X) = \mathrm{tr}(A^\top X)$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $f = \langle A, X\rangle_F$ (الجداء الداخلي الفروبيوس).

٢. $\nabla = A$. ■

- **النتيجة:** A — «مشتقّ الجداء الداخلي هو الطرف الآخر».
- **الربط بالذكاء الاصطناعي:** خسارة «مطابقة مصفوفتين» (مقارنة أنماط) تدرّجها هو المقارَن — نفس منطق $(\hat{y} - y)$ في القياسي.

مثال (9.5-3).

- **المعطيات:** $f(X) = \operatorname{tr}(X^\top X) = \|X\|_F^2$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $df = 2\operatorname{tr}(X^\top dX)$.

٢. $\nabla = 2X$. ■

- **النتيجة:** $2X$ — نظير $2x$ للمتجه.

- **الربط بالذكاء الاصطناعي:** تنظيم الوزن (weight decay) لكل طبقة مصفوفية: تدرّجه يتناسب مع الأوزان نفسها — لهذا weight decay يعمل مثل «انسحاب نحو الصفر».

مثال (9.5-4).

- **المعطيات:** $f(X) = \operatorname{tr}(X^\top A X)$ مع A متماثلة.
- **المطلوب:** ∇_X.
- **الحل:**

١. $df = \operatorname{tr}(dX^\top AX + X^\top A\,dX) = \operatorname{tr}\big((AX + AX)^\top dX\big)$... بترتيب دقيق: $df = 2\operatorname{tr}((AX)^\top dX)$.

٢. $\nabla = 2AX$. ■

- **النتيجة:** $2AX$.

- **الربط بالذكاء الاصطناعي:** «تدرّج الطاقة التربيعية المصفوفية» — نمط القوة الخطّية في أنظمة المربعات الصغرى ثنائية الأبعاد (مصفوفة معاملات بدل متجه).

مثال (9.5-5).

- **المعطيات:** $f(X) = \ln\det X$ على $X \succ 0$، عند $X = \operatorname{diag}(1, 2)$.
- **المطلوب:** ∇ وقيمته.
- **الحل:**

١. $\nabla = X^{-1} = \operatorname{diag}(1, \tfrac{1}{2})$.

٢. $f = \ln 2 \approx 0.693$. ■

- **النتيجة:** التدرّج القطري هو معكوس القيم.

- **الربط بالذكاء الاصطناعي:** «حاجز log-det» يعاقب مصفوفات التباين المنكمشة بعكسها — في GPs يضمن بقاء النواة موجبة التعريف أثناء التحسين.

مثال (5.9-6).

- **المعطيات:** $f(X) = \det X$ لعناصر 2×2.
- **المطلوب:** ∇_X والتحقق من (5.9).
- **الحل:**

١. $\det X = x_{11}x_{22} - x_{12}x_{21}$.

٢. $\nabla = \begin{bmatrix} x_{22} & -x_{21} \\ -x_{12} & x_{11} \end{bmatrix}$.

٣. وهذا هو $\det(X)X^{-1}$ فعلاً (بالمرافق). ■

- **النتيجة:** مصفوفة المرافقة.
- **الربط بالذكاء الاصطناعي:** «مشتقّ المحدّد = المرافق»؛ تفد في تدفّقات طبيعية صغيرة حيث يُحسب أثر تغيّر المحدّد على الكثافة.

مثال (5.9-7).

- **المعطيات:** $f(X) = \operatorname{tr}(X^{-1}A)$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $d(X^{-1}) = -X^{-1}(dX)X^{-1}$.

٢. $df = -\operatorname{tr}(X^{-1}(dX)X^{-1}A) = -\operatorname{tr}(X^{-1}AX^{-1}dX)$.

٣. $\nabla = -X^{-1}A^{\top}X^{-1}$ (ومتماثلة إذا كانت A كذلك). ■

- **النتيجة:** كما في الجدول.
- **الربط بالذكاء الاصطناعي:** تحسين «أثر المعكوس» يظهر في تجميع Fisher المعلوماتي — عقوبات كربوفي المنطقية.

مثال (5.9-8).

- **المعطيات:** $f(X) = \|AX - B\|_F^2$.
- **المطلوب:** ∇_X.
- **الحل:**

١. $df = 2\operatorname{tr}\big((AX - B)^{\top}A\,dX\big)$.

٢. $\nabla = 2A^{\top}(AX - B)$. ■

- **النتيجة:** نظير (4.9) بالمصفوفات.
- **الربط بالذكاء الاصطناعي:** «تحليل القيم المفردة المصغّر» (rank-constrained) وحلّ Procrustes — مشاكل معاملات مصفوفية كاملة (matrix factorization) في أنظمة التوصية).

مثال (9-5.9).

- **المعطيات:** $f(X) = \lambda_{\max}(X)$ للعدد الطيفي عند نقطة القيمة العظمى بسيطة.
- **المطلوب:** ∇ الاتجاهي.
- **الحل:**

١. لقيمة ذاتية بسيطة: $\nabla = \mathbf{v}\mathbf{v}^\top$ حيث $\mathbf{v}$ المتجه الذاتي الموحّد.

٢. خارجها: غير قابلة للاشتقاق (زوايا عند تقاطع قيم). ■

- **النتيجة:** إسقاط رتبة-1 على المتجه الذاتي القائد.

• **الربط بالذكاء الاصطناعي:** «شحاذة شكل الحوض»: sharpness تقاس بـ $\lambda_{\max}(H)$؛ تدرّجها يقود SAM — تخفيف اتجاه المتجه الذاتي الأكبر.

مثال (10-5.9).

- **المعطيات:** $f(\mathbf{x}) = \mathbf{x}^\top H\mathbf{x}$ مع H هِسّية (متماثلة).
- **المطلوب:** الاستقراء الثاني بمنتج Hessian-vector.
- **الحل:**

١. $\nabla = 2(H\mathbf{x})^\top$.

٢. منتج HV: $H\mathbf{v}$ يُحسب بفرق منتهٍ على التدرّج: $H\mathbf{v} \to \frac{\nabla f(\mathbf{x}+\epsilon\mathbf{v}) - \nabla f(\mathbf{x})}{\epsilon}$.

٣. تكلفة: مروران فقط لا $O(n^2)$. ■

- **النتيجة:** Hessian-vector في تكلفة تدرّج.

• **الربط بالذكاء الاصطناعي:** هذه الحيلة تجعل حساب $\lambda_{\max}(H)$ ممكناً للنماذج الضخمة (Lanczos/power iterations على المنتجات) — أساس قياس الشحاذة بدون بناء H.

مثال (11-5.9).

- **المعطيات:** $f(X) = \operatorname{tr}(X)$ مع قيد X متماثلة.
- **المطلوب:** التدرّج على المشعب المتماثل.
- **الحل:**

١. dX متماثل $\Longrightarrow$ فقط الجزء المتماثل من G يهمّ.

٢. إسقاط: $\nabla_{\text{sym}} = \frac{G+G^\top}{2} = I$. ■

- **النتيجة:** الوحدة مرة أخرى (متماثلة أصلاً).

- **الربط بالذكاء الاصطناعي:** «الاشتقاق على مشعب» — بعض المعاملات متماثلة/متعامدة بنيوياً؛ التدرّج يُسقط على مسموح التحديث (Riemannian optimization).

مثال (9.5-12).

- **المعطيات:** $f(Q) = \text{tr}(Q^\top A Q)$ مع Q متعامدة.

- **المطلوب:** التدرّج على مجموعة التعامد (متعرّج).

- **الحل:**

١. تدرّج حرّ: $2AQ$.

٢. إسقاط مائل للتعامد: $G - AQQ^\top$... بالصيغة: $\nabla_{\mathcal{O}} = 2AQ - 2Q\,\text{sym}(Q^\top A Q)$.

٣. للحالة المتماثلة A: يبسط إلى $2[AQ - Q\,\text{diag}(Q^\top A Q)]$. ■

- **النتيجة:** اتجاهات «دورانية» صرفة.

- **الربط بالذكاء الاصطناعي:** PCA و weights: orthogonal التحديث دوراني على مشعب ستيفل — يحفظ التعامد بلا إعادة تكييف (no re-orthogonalization) كل خطوة.

مثال (9.5-13).

- **المعطيات:** $f(X) = \sum_i \lambda_i(X)$ = الأثر (مجموع القيم الذاتية).

- **المطلوب:** ∇.

- **الحل:**

١. $\text{tr}(X) = \sum \lambda_i$ (للمصفوفة المربعة).

٢. $\nabla = I$ — لا اعتماد على القيم الذاتية كائنات. ■

- **النتيجة:** الأثر «أعمى» عن أساس التحييد.

- **الربط بالذكاء الاصطناعي:** «ثبات دوراني»: المعايير المعتمدة على الأثر/القيم لا تتأثر بأساس — لهذا regularization الطيفي ثابت التدوير.

مثال (9.5-14).

- **المعطيات:** $f(\mathbf{x}) = \sqrt{\mathbf{x}^\top \mathbf{x} + \epsilon}$ (نُرم مستقرّة عددياً).
- **المطلوب:** ∇ وقارن مع $\|\mathbf{x}\|_2$.
- **الحل:**

١. $\nabla = \frac{\mathbf{x}^\top}{\sqrt{\mathbf{x}^\top \mathbf{x} + \epsilon}}$.

٢. عند $\mathbf{x} = 0$: التدرّج $0 = 0$ (بلا انفجار) — مختلفة عن $\|\mathbf{x}\|_2$ غير القابلة للاشتقاق. ■

- **النتيجة:** نسخة ناعمة بثابت ϵ.
- **الربط بالذكاء الاصطناعي:** هذا بالضبط مقام LayerNorm $(\sqrt{\sigma^2 + \epsilon})$؛ ϵ يشتري قابلية الاشتقاق في الصفر بأدنى تشويه.

مثال (5.9-15).

- **المعطيات:** $f(X) = \ln\det(X) + \operatorname{tr}(X^{-1}S)$ (دالة الاحتمال الغاوسي المركّزة، مقياس S).
- **المطلوب:** ∇_X ونقطة المثل بالتعويض.
- **الحل:**

١. من (5.9) والمثال 5.9-7: $\nabla = X^{-1} - X^{-1}SX^{-1}$.

٢. الصفر: $X = S$. ■

- **النتيجة:** «تقدير التباين الأعظم» هو S — المشتقّ يؤكد الشهرة.
- **الربط بالذكاء الاصطناعي:** تعلّم calibration: multi-variate / process Gaussian المعادلة نفسها تضبط مصفوفات الدقّة (precision) في نماذج الاحتمال العميقة.

النظرية — يعقوبية softmax

dir="ltr"> <div

Theorem 6.9 (Softmax Jacobian). For $\mathbf{s} = \operatorname{softmax}(\mathbf{z})$:

$$\frac{\partial s_i}{\partial z_j} = s_i(\delta_{ij} - s_j).$$

$$J_{\text{softmax}} = \operatorname{diag}(\mathbf{s}) - \mathbf{s}\,\mathbf{s}^\top \tag{6.9}$$

برهان (6.9).

١. $s_i = \dfrac{e^{z_i}}{S}$، $S = \sum_k e^{z_k}$.

٢. $\dfrac{\partial s_i}{\partial z_j} = \dfrac{\delta_{ij} e^{z_i} S - e^{z_i} e^{z_j}}{S^2} = s_i \delta_{ij} - s_i s_j$. ■

النتيجة الجملية (للاستخدام المباشر): لخسارة انتروبيا متقاطعة $L = -\sum_k y_k \ln s_k$ مع أهداف one-hot:

$$\nabla_{\mathbf{z}} L = \mathbf{s} - \mathbf{y} \tag{7.9}$$

— «التوقّع ناقص الحقيقة» — أنظف تدرّج في التعلم الآلي كله.

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
كتابة $J = \operatorname{diag}(\mathbf{s})$ فقط	نسيان ترابط الصفوف (المجموع = 1)	(6.9) يضمّن الناقص $ss^\top$
حساب تدرّج softmax ثم cross-entropy منفصلين	إهدار وحساسيات أضعف	(7.9) مباشرة — أجمعهما دائماً
نسيان أنّ (6.9) شبه موجبة بالضبط	صفوف J تجمع إلى 0 (قيمة ذاتية صفرية)	softmax ثابت بالإزاحة — إزالة درجة حرية
«∇ على W = تدرّج على $\mathbf{z}$»	بينهما سلسلة واحدة	$\nabla_W = (\mathbf{s} - \mathbf{y})\mathbf{x}^\top$

أمثلة محلولة على التطبيقات (15 مثالاً)

مثال (6.9-1).

- **المعطيات:** $\mathbf{z} = (2, 1, 0)$.
- **المطلوب:** $\mathbf{s} = \operatorname{softmax}(\mathbf{z})$ و J من (6.9) عند الخلية $(1, 1)$.
- **الحل:**

١. $s = (e^2, e^1, 1)/(e^2 + e + 1) \approx (0.665,\ 0.245,\ 0.090)$.

٢. $J_{11} = s_1(1 - s_1) = 0.665 \times 0.335 \approx 0.2227$.

٣. $J_{12} = -s_1 s_2 \approx -0.163$. ■

- **النتيجة:** قيم كما هو.
- **الربط بالذكاء الاصطناعي:** أرقام «معدّل التدفق» الحقيقية لطبقة إخراج مصنّف، القطري دائماً الأكبر — الإشارات الموجبة على الذات.

مثال (6.9-2).

- **المعطيات:** $L = -\ln s_2$ مع $\mathbf{s}$ من المثال السابق (y = الصنف 2).
- **المطلوب:** $\nabla_{\mathbf{z}} L$ من (7.9).
- **الحل:**

١. $\mathbf{y} = (0, 1, 0)$.

٢. $\mathbf{s} - \mathbf{y} \approx (0.665, -0.755, 0.090)$. ■

- **النتيجة:** دفعة نحو الصنف الصحيح بعكس الإشارة.

- **الربط بالذكاء الاصطناعي:** «كل الصفوف تنقص ما عدا الحقيقي» — هذا السطر يُطبع في سجلات التدريب كل خطوة: توقّع ناقص حقيقة.

مثال (9.6-3).

- **المعطيات:** هدف واحد-hot عامّ $\mathbf{y}$.

- **المطلوب:** اشتقّ (9.7) من (9.6).

- **الحل:**

١. $\nabla_z L = -\sum_k y_k \frac{1}{s_k} \frac{\partial s_k}{\partial z_j}$.

٢. بالتعويض: $-\sum_k y_k(\delta_{kj} - s_k) = -y_j + \underbrace{\sum_k y_k}_{1} s_j$.

٣. النتيجة $s_j - y_j$. ■

- **النتيجة:** (9.7) عامّة.

- **الربط بالذكاء الاصطناعي:** «الاختزال» الذي يوفر حساب $\frac{1}{s_k}$ (انفجار محتمل) — الدمج الرياضي بدل الحساب المنفصل يقتل مشكلة العددية.

مثال (9.6-4).

- **المعطيات:** انحدار خطّي ببيانات $X \in \mathbb{R}^{n \times d}$.

- **المطلوب:** ∇_w لخسارة MSE وحلّها المغلق.

- **الحل:**

١. $L = \frac{1}{n}\|X\mathbf{w} - \mathbf{y}\|^2$؛ $\nabla = \frac{2}{n} X^\top (X\mathbf{w} - \mathbf{y})$.

٢. الصفر: $X^\top X \mathbf{w} = X^\top \mathbf{y}$.

٣. $\mathbf{w}^* = (X^\top X)^{-1} X^\top \mathbf{y}$ (رتبة كاملة). ■

- **النتيجة:** المعادلة الطبيعية.

- **الربط بالذكاء الاصطناعي:** «الحل المغلق المرجعي» الذي نقيس عليه كل المحسّنات التدريجية؛ وبشكله $X^\top X$ يذكّرنا بشرط κ^2 من فصل 6.

مثال (9.6-5).

- **المعطيات:** انحدار ريدج: $L = \frac{1}{n}\|X\mathbf{w} - \mathbf{y}\|^2 + \lambda\|\mathbf{w}\|^2$.
- **المطلوب:** الحل المغلق.
- **الحل:**

١. $\nabla = \frac{2}{n}X^\top(X\mathbf{w} - \mathbf{y}) + 2\lambda\mathbf{w}$.

٢. $\mathbf{w}^* = (X^\top X + n\lambda I)^{-1}X^\top\mathbf{y}$. ■

- **النتيجة:** إضافة $n\lambda I$ تجعل المعكوس ممكناً دائماً.

- **الربط بالذكاء الاصطناعي:** «ريج = إصلاح المفردة»: الفصل 6 كشف أنّ $\kappa(A^\top A)$ يكاد يكون مربّعاً؛ إزاحة القطر تُخفض الشرط وتضمن وجوداً.

مثال (9.6-6).

- **المعطيات:** الانحدار اللوجستي متعدد الصفوف: $\hat{\mathbf{y}} = \text{softmax}(W\mathbf{x})$، خسارة متقاطعة.
- **المطلوب:** ∇_W لعينة واحدة.
- **الحل:**

١. من (9.7): $\nabla_z = (\hat{\mathbf{y}} - \mathbf{y})$.

٢. سلسلة: $\nabla_W = (\hat{\mathbf{y}} - \mathbf{y})\mathbf{x}^\top$. ■

- **النتيجة:** مصفوفة خارجية خطأ×مدخل.

- **الربط بالذكاء الاصطناعي:** هذه «الطبقة النهائية» لكل مصنّف؛ التحديث الصفّي: صفّ الحقيقة يرتفع وصفوف التوقّع الخاطئة تنخفض.

مثال (9.6-7).

- **المعطيات:** LayerNorm لعدد واحد: $g(\mathbf{x}) = \frac{\mathbf{x}-\mu\mathbf{1}}{\sqrt{\sigma^2+\epsilon}} \odot \boldsymbol{\gamma} + \boldsymbol{\beta}$.
- **المطلوب:** بنية اليعقوبية (دون تفصيل كامل).
- **الحل:**

١. ثلاث مسارات: عبر المقام (رتبة كاملة)، عبر μ (رتبة-1)، عبر σ^2 (رتبة-1).

٢. $J = J_{\text{مقام}} + J_\mu + J_{\sigma^2}$؛ كل مسار له عامل قياس.

٣. عملياً: backprop يجمع المسارات الثلاثة. ■

- **النتيجة:** يعقوبية مجموع ثلاث إسهامات.

- **الربط بالذكاء الاصطناعي:** هذا «الشتّاء الرياضي» الذي يفاجئ من يكتب LayerNorm يدوياً — المكتبات تختصره؛ المسارات الثلاثة هي أسباب أخطاء التدرّج الشائعة في التنفيذ المنزلي.

مثال (6.9-8).

- **المعطيات:** انتباه ذاتي لعنصر واحد: $\text{Attn}(\mathbf{q},\mathbf{K},\mathbf{V})=\sum_j \alpha_j \mathbf{v}_j$، $\alpha=\text{softmax}(\mathbf{q}^\top \mathbf{k}_j/\sqrt{d})$.
- **المطلوب:** صيغة تدرّج $\mathbf{q}$.
- **الحل:**

١. J_α من (6.9) بحجم n (عدد الرؤوس/السياق).

٢. $\nabla_q=\sum_j \frac{\partial L}{\partial \alpha_j}\cdot\frac{\partial \alpha_j}{\partial \mathbf{q}}=\sum_{j,l}\frac{\partial L}{\partial \alpha_j}J_{\alpha,jl}\frac{\mathbf{k}_l}{\sqrt{d}}$.

٣. شكل مصفوفي: $\nabla_{\mathbf{q}}=\frac{1}{\sqrt{d}}K^\top\left[J_\alpha^\top\frac{\partial L}{\partial \boldsymbol{\alpha}}\right]$. ■

- **النتيجة:** يعقوبية softmax داخل الانتباه.

• **الربط بالذكاء الاصطناعي:** «تراكب الانتباه» تحسبها flash-attention ضمنياً، بنية (6.9) نفسها، بالحجم الذي يفرض تحسينات الذاكرة.

مثال (6.9-9).

- **المعطيات:** $L=\frac{1}{2}\|W\|_F^2+\lambda\|WX-\mathbf{t}\|^2$.
- **المطلوب:** ∇_W.
- **الحل:**

١. $\nabla=\lambda\cdot 2(WX-\mathbf{t})X^\top+W$.

٢. قابلية حلّ خطي في W (محدّبة في W). ■

- **النتيجة:** $2\lambda(WX-\mathbf{t})X^\top+W$.

• **الربط بالذكاء الاصطناعي:** «اختناق عائد مشترك» بوجود المصفوفة الازدواجية؛ مشاكل معاملات كاملة تُحلّ خطيّاً بذلك الشكل — انحدار سجلات (logistic) بمعاملات بديلة.

مثال (6.9-10).

- **المعطيات:** $L=\|\text{diag}(\mathbf{s})-\mathbf{s}\mathbf{s}^\top\|_F$؟ بديلاً: احسب القيم الذاتية لـ (6.9).
- **المطلوب:** أثبت أنّ (6.9) شبه موجبة بقيمة ذاتية صفرية على $\mathbf{1}$.
- **الحل:**

١. $J\mathbf{1}=\mathbf{s}-\mathbf{s}(\mathbf{s}^\top\mathbf{1})=\mathbf{s}-\mathbf{s}=0$.

٢. لأيّ $\mathbf{v}$: $\mathbf{v}^\top J\mathbf{v} = \sum_i s_i v_i^2 - (\sum_i s_i v_i)^2 = \mathrm{Var}_s(v) \geq 0$.

٣. إذن $J \succeq 0$ مع نواة $\mathrm{span}(\mathbf{1})$. ■

- **النتيجة:** شبه موجبة، مفرّدة بدرجة.

- **الربط بالذكاء الاصطناعي:** softmax» لا يرى الإزاحة» — درجة حرية مفقودة؛ لهذا logits تُعالج بإزاحة عشوائية بأمان، ولماذا الدرجة الحرارة تُقارن بالأسّ فقط.

مثال (9.6-11).

- **المعطيات:** $L(\mathbf{w}) = \frac{1}{n}\sum_i \ln(1 + e^{-y_i \mathbf{w}^\top \mathbf{x}_i})$ $(y_i \in \{\pm 1\})$.

- **المطلوب:** التدرّج وقرنته بالصيغة ثنائية الصنف.

- **الحل:**

١. $\nabla = \frac{1}{n}\sum_i -\sigma(-y_i \mathbf{w}^\top \mathbf{x}_i)\, y_i \mathbf{x}_i^\top$.

٢. بصيغة $\{0,1\}$: $(\hat{y}_i - y_i)\mathbf{x}_i^\top$ — التان.

٣. متكافئان. ■

- **النتيجة:** $\frac{1}{n}\sum_i (\sigma(y_i w^\top x_i) - 1) y_i x_i^\top$.

- **الربط بالذكاء الاصطناعي:** صيغة ± 1 لطيفة في SVM-adjacent الأدبيات، صيغة $\{0,1\}$ في backprop — نفس الرياضيات بلغتين.

مثال (9.6-12).

- **المعطيات:** $L = \|\mathbf{g}\|^2$ حيث $\mathbf{g} = \nabla_{\mathbf{w}} f(\mathbf{w})$ (خسارة تدرّج-مربّع — هدف في SAM/bilevel).

- **المطلوب:** الهِسّية الظاهرة (Hessian-vector).

- **الحل:**

١. $\nabla_{\mathbf{w}} L = 2J_g^\top \mathbf{g} = 2H\,\nabla f$.

٢. «هِسّية × تدرّج» — يتطلب منتج HV.

٣. بالفروق على التدرّج: مروران إضافيان. ■

- **النتيجة:** $2H\nabla f$.

- **الربط بالذكاء الاصطناعي:** «تدرّج التدرّج» — محرّك محسّنات المستوى الثاني Newton) بلا تربيعات) وأهداف الشحاذة، إضافته تكلف مضاعفة وقت الدفعة.

مثال (9.6-13).

- **المعطيات:** Adam: $\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1-\beta_2)\mathbf{g}_t^2$ (عنصرياً) ثم $\Delta w = -\eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\epsilon}$.
- **المطلوب:** تفسير المقام بلغة الهِسّية القطرية التقريبية.
- **الحل:**

١. $\hat{v}_t \approx$ متوسط مربّعات التدرّج $\approx$ تقدير H_{ii} القطري (لنماذج محدّبة تقريباً).

٢. القسمة = تحديد مسبق قطري (preconditioning) — تقريب لطريقة نيوتن بقطرية فقط.

٣. التكلفة: ذاكرة ضعف الأوزان. ■

- **النتيجة:** Adam $\approx$ Newton قطري مبسّط بمعدّل صغير.
- **الربط بالذكاء الاصطناعي:** هذه قرنة نظريّة شائعة لنجاح Adam على أحواض ill-conditioned (فصل 6 وأمثلة 9.3-9): تعديل القيم الذاتية القطرية يدوياً.

مثال (9.6-14).

- **المعطيات:** $L = |\mathbf{w}^\top \mathbf{x} - y|$ بعيّنة واحدة، مدخل $\mathbf{x} \neq 0$.
- **المطلوب:** subgradient ونقاط «الشوكة».
- **الحل:**

١. $\nabla = \operatorname{sgn}(\mathbf{w}^\top \mathbf{x} - y)\, \mathbf{x}^\top$.

٢. عند $\mathbf{w}^\top \mathbf{x} = y$: مجموعة كاملة $\{\lambda \mathbf{x}^\top : |\lambda| \le 1\}$.

٣. شوكة على «المستوي العمودي على $\mathbf{x}$». ■

- **النتيجة:** subgradient متجه كامل.
- **الربط بالذكاء الاصطناعي:** انحدار LAD: «التوقّف عند أول بلوغ» — المستوى الجداري؛ لهذا L1 يصنع حلولاً على «حواف» الفضاء (تناثر هندسي).

مثال (9.6-15).

- **المعطيات:** شبكة من طبقتين بإخراج softmax: $\hat{\mathbf{y}} = \operatorname{softmax}(W_2 \operatorname{ReLU}(W_1 \mathbf{x}))$ وخسارة متقاطعة.
- **المطلوب:** التدرّج الكامل لـ W_1 بسطور معدودة.
- **الحل:**

١. $\boldsymbol{\delta}_2 = \hat{\mathbf{y}} - \mathbf{y}$ (من 7.9).

٢. $\boldsymbol{\delta}_1 = W_2^\top \boldsymbol{\delta}_2 \odot \mathbb{1}[\mathbf{z}_1 > 0]$ (قناع ReLU).

٣. $\nabla_{W_1} = \boldsymbol{\delta}_1 \mathbf{x}^\top$. ■

- **النتيجة:** ثلاثة أسطر — كل backprop.
- **الربط بالذكاء الاصطناعي:** هذا «أصغر مثال كامل» للانتشار العكسي عبر تنشيط غير خطي — كل شبكة حقيقية تكرار لهذه الأسطر بمقاييس ضخمة.

خيط الفصل

١. **اليعقوبية (1.9)** تعمّم المشتقّ: كل التدفق بين الطبقات يوصف بمصفوفة حساسيات.

٢. **الهِسّية (2.9)** تحوّل «شكل الحوض» إلى مصفوفة قيم ذاتية — والقيم الذاتية تحكم سرعة التقارب (جسر مباشر إلى فصل 6).

٣. **السلسلة (3.9)** تضاعف اليعقوبيات — والضرب المتكرر هو «نهر التلاشي/الانفجار».

٤. **القواعد الأثرية (5.9)** تسرّع كل الحساب: مشتقّ الأثر نقل، ومشتقّ log-det معكوس.

٥. **التطبيقات (6.9)** تعطينا «كنز الصيغ»: $\nabla L = \hat{y} - y$ للوجستياً، $J = \mathrm{diag}(s) - ss^\top$ لـsoftmax، و $\mathbf{w}^* = (X^\top X + \lambda I)^{-1} X^\top \mathbf{y}$ لريج.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
اليعقوبية	autograd بالكامل (فصل 36)
$H \succeq 0$	براهين محدّبية الخسارة (فصل 40)
$J = \mathrm{diag}(s) - ss^\top$	تصنيفات softmax النهائية
$2A^\top(Ax - b)$	المحسّنات الخطّية المربعة
Hessian-vector	SAM وشحاذة النماذج الضخمة
إسقاط التدرّج	مشابك التعامد (منها ortho) attention

١. احسب اليعقوبية لـ $\mathbf{f}(x, y) = (xy,\ x/y)$، وحدّد أين تنشذ.

٢. أثبت أنّ $J_{A\mathbf{x}} = A$ و $J_{A\mathbf{x}+\mathbf{b}} = A$ (لا تعتمد على $\mathbf{b}$).

٣. احسب $\nabla_{\mathbf{x}} \mathbf{x}^\top A \mathbf{x}$ لـ $A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}$، وتحقّق من صيغة $A + A^\top$.

٤. أوجد اليعقوبية لـ $\mathbf{f}(\mathbf{x}) = \mathbf{x}/\|\mathbf{x}\|_1$ (عند $\mathbf{x} \neq 0$، أولًا فرديًا).

٥. احسب الهِسّية لـ $f(x, y) = e^{x^2 + y^2}$ وحدّد مناطق التقوّس.

٦. طبّق اختبار المشتقّ الثاني للدالة $f(x, y) = x^2 + y^2 - xy + x$.

٧. أوجد نقاط السرج للدالة $f(x, y) = x^3 - 3xy^2$ (دالة مونج-أمبير) وتصنيف النقطة الحرجة الوحيدة.

٨. اشتقّ $\nabla_X \mathrm{tr}(X^2)$ ثم $\nabla_X \mathrm{tr}(X^k)$ (استقراءً).

٩. أثبت من التفاضل أنّ $\nabla_X \|X\|_F = \frac{X}{\|X\|_F}$ عند $X \neq 0$.

١٠. احسب يعقوبية softplus المتجهة $\mathrm{softplus}(\mathbf{z})$ وقارنها بسيجمويد (هي نفسها!).

١١. أثبت أنّ صفوف J_{softmax} تجمع إلى الصفر، وفسّر بدلالة «ثبات الإزاحة».

١٢. احسب ∇_W لخسارة $-\ln(\mathrm{softmax}(W\mathbf{x})_2)$ وأوجد قيمتها عند $\mathbf{x} = (1, 1)$، $W = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$.

١٣. أثبت أنّ خسارة MSE لريج مع $\lambda > 0$ لها صغرى عالمية وحيدة حتى لو كانت X مفردة.

١٤. طبّق قاعدة السلسلة لثلاث دوال: $\mathbf{x} \to A\mathbf{x} \to \mathrm{ReLU} \to B\cdot \to \|\cdot\|^2$ واكتب التدرّج النهائي.

١٥. أثبت متباينة التدرّج: $\|f(\mathbf{y}) - f(\mathbf{x})\| \le \sup_t \|J_f(\mathbf{x} + t(\mathbf{y}-\mathbf{x}))\| \, \|\mathbf{y}-\mathbf{x}\|$ (بتكامل أو MVT مصفوفي).

١٦. احسب Hessian-vector product لـ $f(\mathbf{x}) = \frac{1}{2}\|A\mathbf{x} - \mathbf{b}\|^2$ بخطوتين (تدرّج ثم فارق).

١٧. أوجد $\nabla_X \ln\det(X)$ عند $X = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}$ وقارن بالحساب المباشر.

١٨. اكتب backprop كاملاً لشبكة: $\hat{y} = w_2 \tanh(w_1 x)$ بخسارة $\frac{1}{2}(\hat{y} - y)^2$ (كل التدرّجات).

١٩. أثبت أنّ softmax هو حلّ مسألة تعظيم الإنتروبيا السلبية على simplex بمتوسط مقيد (لاغرانج — استباقاً).

٢٠. تحدٍّ تركيبي: «لماذا أضافت ϵ إلى LayerNorm؟» — احسب تدرّج $\frac{x}{\sqrt{\sigma^2+\epsilon}}$ عند $\mathbf{x} = 0$، وقارنه بالمشتق بلا ϵ، وربط بالأخطاء العددية للفصل 6 (الإلغاء والحساسية).

- **اليعقوبية (1.9):** $J_{ij} = \partial f_i / \partial x_j$ — خريطة الحساسيات الكاملة؛ التدرّج حالة خاصة.
- **الهِسّية (2.9):** متماثلة (شوارتز)، وقيمها الذاتية تصنّف النقاط الحرجة (حوض/سرج/قمة) وتقيس الـ conditioning.
- **السلسلة (3.9):** $J_{g\circ f} = J_g J_f$ — أمامياً بـ A، عكسياً بـ $A^\top$؛ الضرب المتكرر هو التلاشي/الانفجار.
- **القواعد الأثرية (5.9):** $\nabla \mathrm{tr}(AX) = A^\top$، $\nabla \ln\det = X^{-1}$ — أدوات الحساب السريع.
- **كنوز التطبيق (6.9)–(7.9):** softmax يعقوبيتها $\mathrm{diag}(s) - ss^\top$؛ مع cross-entropy تختزل إلى $\mathbf{s} - \mathbf{y}$؛ والريج إلى $(X^\top X + \lambda I)^{-1} X^\top \mathbf{y}$.

الرمز	المعنى	أين عُرّف
$J_{\mathbf{f}}$	اليعقوبية $m \times n$	(1.9)
$\nabla_{\mathbf{x}} f$	التدرّج (صفّ)	قسم 2.9
$H = \nabla^2 f$	الهِسّية	(2.9)
$H \succeq 0$	شبه موجبة (محدَّبة)	نظرية 2.3.9
$J_{g\circ f} = J_g J_f$	السلسلة	(3.9)
$\mathrm{diag}(\mathbf{s}) - \mathbf{s}\mathbf{s}^\top$	يعقوبية softmax	(6.9)
$\mathbf{s} - \mathbf{y}$	تدرّج cross-entropy	(7.9)

١. H. Neudecker, & J. Magnus, (2019). *Matrix Differential Calculus*, 3rd ed., Wiley — المرجع الكنسي لقواعد الأثر والتفاضل المصفوفي.

٢. K. Petersen, & M. Pedersen, (2012). *The Matrix Cookbook* — جداول جاهزة لمشتقّات المصفوفات (مرجع سريع).

٣. A. Griewank, & A. Walther, (2008). *Evaluating Derivatives*, SIAM — التفاضل الآلي: اليعقوبية والهِسّية بكفاءة.

٤. S. Wright, & J. Nocedal, (2006). *Numerical Optimization*, 2nd ed., Springer (الفصل 2: النظرية غير المقيّدة والهِسّية؛ الفصل 3: الأشكال الثنائية).

٥. I., Goodfellow, Y. Bengio, & A. Courville, (2016). *Deep Learning*, MIT Press (الفصل 6: التفاضل المصفوفي للشبكات).

٦. L. Vandenberghe, & S. Boyd, (2004). *Convex Optimization*, Cambridge (الفصل 3: التقوّس و Hessian؛ الفصل 9: تدرّج القيود).

٧. A. Baydin, et al. (2018). "Automatic Differentiation in Machine Learning: a Survey". *JMLR* 18 — مسح شامل للتفاضل الآلي الأمامي/العكسي.

٨. A. Vaswani, et al. (2017). "Attention Is All You Need". *NeurIPS* — softmax الانتباه الذي بنينا تدرّجه في مثال 6.9-8.

التكامل، نظرية القياس، وتكامل ليبيسغ–ستيلتjes

الهدف من الفصل

رابع فصول الجزء الثاني (التفاضل والتكامل). أنهينا النهايات (7) والمشتقّ القياسي (8) والتفاضل المصفوفي (9). الآن ننتقل من «الاشتقاق» إلى «التكامل» لكن بأساسٍ صارم: نظرية القياس. كلّ «توقّع» (expectation) في التعلم الآلي هو تكامل ليبيسغ–ستيلتjes على فضاء الاحتمال، وكل «مخاطرة متوقّعة» (expected risk) هي $\int L \, d\mathbb{P}$. بلا هذا الفصل لا معنى رياضيّ دقيق لـ divergence KL ولا لـ ELBO ولا لـ SDE. dffiusion

أربعة دوافع تجعل هذا الفصل غير قابل للتجاوز:

١. **الاشتقاق والتكامل ليسا متناظرين:** تكامل ريمان ينهار على دوالّ «قفزات كثيفة» (مثل دالة ديريكليه) التي تظهر طبيعياً في الاحتمالات (متغيّرات عشوائية مختلطة). تكامل ليبيسغ يتعامل معها بسلاسة.

٢. **التوقّع هو تكامل:** $\mathbb{E}[X] = \int X \, d\mathbb{P}$؛ و «تكامل ليبيسغ–ستيلتjes» هو بالضبط ما يربط التوزيع (دالة كثافة التوزيع F) بالتوقّع — أساس كل إحصاء في الذكاء الاصطناعي.

٣. **مبرهنات التقارب** (MCT / Fatou / DCT) هي «الأدوات القانونية» التي تسمح بتبادل الحدّ والتكامل — وهو ما نفعله كلّما حوّلنا مجموع خسائر على عيّنات إلى توقّع على التوزيع.

٤. **التعلّم الإحصائي** (الجزء السادس لاحقاً) يقوم على قياس «المسافة» بين توزيعات — وهي مفاهيم قياسية صرفة.

خريطة الفصل

القسم	الموضوع	الأداة المركزية
1.10	فضاءات القياس وسيغما-جبرا	$(\Omega, \mathcal{F}, \mu)$
2.10	قياس ليبيسغ والقياس الخارجي	الترجمة-ثابت $m(E)$
3.10	الدوال القياسية والدوال البسيطة	$\phi = \sum a_i \mathbf{1}_{A_i}$
4.10	تكامل ليبيسغ	$\int f \, d\mu$
5.10	مبرهنات التقارب	DCT · Fatou · MCT
6.10	تكامل ليبيسغ–ستيلتjes	$\int h \, dF$

التعريف

Definition 1.2.10 (σ-algebra & measure). Let Ω be a set. A collection $\mathcal{F} \subseteq 2^{\Omega}$ is a **σ-algebra** fi (i) $\varnothing \in \mathcal{F}$; (ii) $A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$; (iii) $A_1, A_2, \dots \in \mathcal{F} \Rightarrow \bigcup_n A_n \in \mathcal{F}$.
A **measure** is $\mu : \mathcal{F} \to [0, \infty]$ with $\mu(\varnothing) = 0$ and **countable additivity**:

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n) \quad \text{disjoint for} A_n \in \mathcal{F}. \tag{1.10}$$

dir="ltr"> <div
space. probability a is it $\mu(\Omega) = 1$ If **.space measure** a is $(\Omega, \mathcal{F}, \mu)$ triple The

النظرية 1.2.10 (الاستمرارية). لقياس μ ومتتاليات $A_n \uparrow A$ (تصاعدياً) أو $B_n \downarrow B$ مع $\mu(B_1) < \infty$ (هبوطياً):

$$\mu(A) = \lim_{n\to\infty} \mu(A_n), \qquad \mu(B) = \lim_{n\to\infty} \mu(B_n).$$

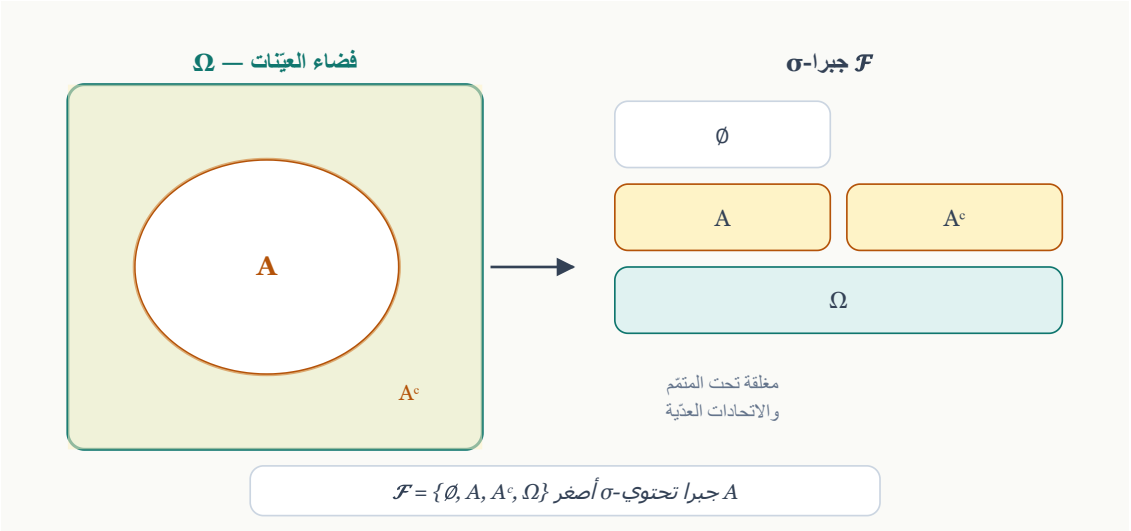
النظرية 2.2.10 (الإنحماد). لـ $A \subset B$: $\mu(A) \le \mu(B)$؛ ولأيّ A, B: $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$.

جدول الرموز

الرمز	الاسم	المعنى
Ω	فضاء العيّنات	المجموعة الكلية للنتائج
$\mathcal{F}$	سيغما-جبرا	عائلة المجموعات «القياسية»
μ	القياس	دالة حجم غير سالبة قابلة للجمع عدّياً
$\sigma(\mathcal{C})$	σ-جبرا المولّدة	أصغر σ-جبرا تحوي $\mathcal{C}$

رسم توضيحي

<figure> الشكل<figcaption> 1.10: σ-جبرا $\mathcal{F}$ ليست «كل المجموعات الفرعية» بل أصغر عائلة مغلقة تحت المتمّم



شكل ١٠.١٠: *
سيغما-جبرا كأصغر عائلة مغلقة تحت المتمّم والاتحاد

والاتحادات العدّية. لنقطة/مجموعة A نحصل على العائلة الرباعية $\{\emptyset, A, A^c, \Omega\}$.</figcaption></figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«الاتحاد المنتهي يكفي»	σ-جبرا تتطلّب اتحادات عدّية لا منتهية فقط	الاتحاد المنتهي ناتج عن شرطي (ii),(iii)
نسيان أنّ $\mu(\emptyset)=0$ إلزامي	بلاها ينهار الجمع العدّي	ابدأ كل برهان بها
اعتبار 2^Ω دائماً هي σ-جبرا المناسبة	أحياناً «كبيرة أكثر from اللازم» (غير قياسية)	استخدم $\sigma(\mathcal{C})$ الأصغر المناسبة
الخلط بين «مجموعة قياسية» و«لها قياس منتهٍ»	القياس قد يصل ∞	شرط مستقلّ $\mu(A)<\infty$

أمثلة محلولة على فضاءات القياس وسيغما-جبرا (15 مثالاً)

مثال (10،2-1).

- **المعطيات:** $\Omega=\{1,2,3\}$، $\mathcal{F}=2^\Omega$.
- **المطلوب:** تحقّق أنّ $\mathcal{F}$ σ-جبرا وحدّد قياساً عليها.
- **الحل:**

١. $\emptyset\in\mathcal{F}$ واضح؛ المتمّمات والاتحادات تبقى ضمن الـ 8 مجموعات.

٢. عرّف $\mu(A)=|A|$ (قياس العدّ).

٣. $\mu(\emptyset)=0$، ولمنفصلة A,B: $\mu(A\cup B)=|A|+|B|$. ■

- **النتيجة:** 2^Ω أكبر σ-جبرا دائماً، μ قياس عدّ.

- **الربط بالذكاء الاصطناعي:** قياس العدّ على فضاء منتهٍ = «توزيع احتمال منفصل»؛ كل شبكة تصنيف تُعلّم احتمالات $\mu(\{\text{صنف}\})$.

مثال (10،2-2).

- **المعطيات:** $\Omega=\{a,b,c\}$، $A=\{a\}$.
- **المطلوب:** أصغر σ-جبرا تحتوي A.
- **الحل:**

١. نبدأ بـ $\emptyset,\Omega$ و A.

٢. المتمّم $A^c=\{b,c\}$ يجب أن يكون موجوداً.

٣. لا اتحادات جديدة (الأربعة مغلقة). ■

- **النتيجة:** $\mathcal{F}=\{\emptyset,\{a\},\{b,c\},\Omega\}$.

- **الربط بالذكاء الاصطناعي:** «تقسيم الفضاء إلى خلايا» — أصغر σ-جبرا = أضعف قدرة على التمييز؛ أساس ميزات التجميع (clustering) الخشنة.

مثال (2.10-3).

- **المعطيات:** $\Omega = \mathbb{R}$، $\mathcal{C}$ = كل الفترات المفتوحة (a, b).
- **المطلوب:** ما $\sigma(\mathcal{C})$؟
- **الحل:**

١. الفترات المفتوحة تولّد **سيغما-جبرا بوريل** $\mathcal{B}(\mathbb{R})$.

٢. كل فترة مغلقة/نصف مفتوحة/نقطة منتمية لها (مثلاً $\{x\} = \bigcap_n (x - 1/n, x + 1/n)$). ■

- **النتيجة:** $\mathcal{B}(\mathbb{R})$ تحتوي كل المجموعات «العملية» (فترات، نقاط، أقراص مفتوحة).

- **الربط بالذكاء الاصطناعي:** كل دوالّ الاحتمال المستمرّة «بوريل-قياسية» — هذا يجعل احتمال أيّ حدث $(X \le x)$ معرّفاً.

مثال (2.10-4).

- **المعطيات:** $A_1, A_2, \ldots$ منفصلة، $\mu(A_n) = 2^{-n}$.
- **المطلوب:** $\mu\left(\bigcup_n A_n\right)$.
- **الحل:**

١. بالجمع العدّي (1.10): $\sum_{n=1}^{\infty} 2^{-n} = 1$. ■

- **النتيجة:** 1.

- **الربط بالذكاء الاصطناعي:** «هندسة الاحتمالات اللانهائية» — مجموع كثافات نقاط = 1، تماماً كتوزيع احتمالي على عدد لا نهائي من الأصناف (مثل نموذج لغوي).

مثال (2.10-5).

- **المعطيات:** $A_n \uparrow A$، $\mu(A_n) = 1 - 1/n$ على فضاء بـ $\mu(A) = 1$.
- **المطلوب:** تحقّق الاستمرارية من الأسفل.
- **الحل:**

١. $A_n \subset A_{n+1}$ و $\bigcup A_n = A$.

٢. النظرية 1.2.10: $\lim \mu(A_n) = \lim(1 - 1/n) = 1 = \mu(A)$. ■

- **النتيجة:** $\mu(A_n) \to \mu(A)$ (= الاستمرارية من الأسفل).

- **الربط بالذكاء الاصطناعي:** تقارب سلسلة تدريب تدريجياً نحو «الحل الكامل» — قياس «المجموعة المكتشفة» يزداد إلى القيمة النهائية.

مثال (2.10-6).

- **المعطيات:** $B_n \downarrow \{0\}$، $B_n = [-1/n, 1/n]$، $\mu =$ ليبيسغ.
- **المطلوب:** $\lim \mu(B_n)$ مع التحقّق من شرط الانهماك المحدود.
- **الحل:**

١. $\mu(B_1) = 2 < \infty$ (منهدم محدود).

٢. $\mu(B_n) = 2/n \to 0 = \mu(\{0\})$. ■

- **النتيجة:** 0 — نقطة لها قياس صفر.
- **الربط بالذكاء الاصطناعي:** «النقطة الواحدة بلا وزن» في التوزيعات المستمرّة — سبب أنّ $P(X = x) = 0$ دائماً للمتغيّر المستمرّ.

مثال (2.10-7).

- **المعطيات:** μ قياس، $A \subset B$، $\mu(B) = 5$.
- **المطلوب:** حدود $\mu(A)$ والأعمدة.
- **الحل:**

١. بالإنحماد: $0 \le \mu(A) \le 5$.

٢. $\mu(B \setminus A) = \mu(B) - \mu(A) = 5 - \mu(A)$ (لأنّ B منتهية). ■

- **النتيجة:** $\mu(A) \in [0, 5]$.
- **الربط بالذكاء الاصطناعي:** «الخطأ على مجموعة فرعية $\le$ الخطأ الكلّي» — أساس كل تقدير خطأ علوي (upper bound) في التعلّم.

مثال (2.10-8).

- **المعطيات:** $\mu(A) = 3,\ \mu(B) = 4,\ \mu(A \cap B) = 1$.
- **المطلوب:** $\mu(A \cup B)$.
- **الحل:**

١. النظرية 2.2.10: $3 + 4 - 1 = 6$. ■

- **النتيجة:** 6.
- **الربط بالذكاء الاصطناعي:** مبدأ الشمول والاستبعاد (قانون 2.1) هو حالة منتهية من قابلية الجمع — نفس الرياضيات تربط الفصلين 1 و10.

مثال (2.10-9).

- **المعطيات:** $\Omega = \mathbb{R}$، $\mu =$ قياس ليبيسغ، $A = \{7\}$.
- **المطلوب:** $\mu(A)$.
- **الحل:**

١. نقطة = تقاطع فترات $[7, 7 + 1/n]$؛ قياسها $\leq 1/n$ لكل n.

٢. إذن $\mu(\{7\}) = 0$. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** مستمرّ $\neq$ منفصل؛ النقاط بلا كتلة — لذلك نحتاج كثافة $p(x)$ لا احتمال نقطي.

مثال (2.10-10).

- **المعطيات:** $\mu(\Omega) = 1$، الأحداث A, B بـ $\mu(A) = 0.6, \mu(B) = 0.4, \mu(A \cap B) = 0.2$.
- **المطلوب:** هل μ احتمال؟ وما $\mu(A \cup B)$؟
- **الحل:**

١. $\mu(\Omega) = 1$ والمتطلّبات محقّقة $\Longrightarrow$ مساحة احتمال.

٢. $\mu(A \cup B) = 0.6 + 0.4 - 0.2 = 0.8$. ■

- **النتيجة:** احتمال، الاتحاد 0.8.
- **الربط بالذكاء الاصطناعي:** جدول احتمالات مشترك (join) (probability — أساس بايز والشبكات الاحتمالية.

مثال (2.10-11).

- **المعطيات:** X, Y فضاءان، $\mathcal{F}_X, \mathcal{F}_Y$ σ-جبرات.
- **المطلوب:** عرّف σ-جبرا الجداء على $X \times Y$.
- **الحل:**

١. $\mathcal{F}_X \otimes \mathcal{F}_Y = \sigma(\{A \times B : A \in \mathcal{F}_X, B \in \mathcal{F}_Y\})$.

٢. تولّد من «مستطيلات قياسية». ■

- **النتيجة:** σ-جبرا الجداء.
- **الربط بالذكاء الاصطناعي:** فضاء الميزات المشترك (صورة × نص) — أحداثه منتجات أحداث أصلية؛ أساس نماذج الاحتمال المشترك.

مثال (12-2.10).

- **المعطيات:** $\Omega = \{1, 2\}$، $\mathcal{F} = \{\emptyset, \Omega\}$ (σ-جبرا تافهة).
- **المطلوب:** هل يمكن لدالة $f : \Omega \to \mathbb{R}$ أن تكون غير ثابتة وقابلة للقياس؟
- **الحل:**

١. $\{\omega : f(\omega) > a\}$ يجب أن تكون $\emptyset$ أو Ω لكل a.

٢. هذا يفرض $f(1) = f(2)$ دائماً. ■

- **النتيجة:** كل دالة قياسية هنا ثابتة.

- **الربط بالذكاء الاصطناعي:** «أضعف σ-جبرا = أقلّ معلومات» — مشابه لما لا تستطيع طبقة بلا ميزات تمييزه؛ ربط بالتعلّم غير القابل للتعلّم VC) بعداً).

مثال (13-2.10).

- **المعطيات:** $\mathcal{A} = \{\emptyset, \{1\}\}$، $\mathcal{B} = \{\emptyset, \{2\}\}$ على $\Omega = \{1, 2, 3\}$.
- **المطلوب:** هل اتحاد $\mathcal{A} \cup \mathcal{B}$ σ-جبرا؟
- **الحل:**

١. $\{1, 2\} = \{1\} \cup \{2\}$ يجب أن يكون عضواً لكنه ليس في الاتحاد.

٢. إذن الاتحاد ليس σ-جبرا. ■

- **النتيجة:** لا.

- **الربط بالذكاء الاصطناعي:** «دمج ميزاتين» لا يكفي أحياناً — يجب أخذ الـ σ-جبرا المولّدة (كل التفاعلات)، تماماً كدمج مميّزات في شبكة.

مثال (14-2.10).

- **المعطيات:** $\mathcal{C} = \{(-\infty, a] : a \in \mathbb{R}\}$.
- **المطلوب:** أثبت أنّ $\sigma(\mathcal{C}) = \mathcal{B}(\mathbb{R})$.
- **الحل:**

١. كل $(-\infty, a]$ بوريل $\Longrightarrow \sigma(\mathcal{C}) \subset \mathcal{B}$.

٢. العكس: $(a, b] = (-\infty, b] \setminus (-\infty, a]$ بوريل، والفترات نصف المفتوحة تولّد $\mathcal{B}$. ■

- **النتيجة:** تتساوى.

- **الربط بالذكاء الاصطناعي:** $F(x) = P(X \leq x)$ تُعرّف على $(-\infty, a]$ — لهذا التوزيعات تُحدَّد بـ CDF يسار-مستمر لا بالكثافة.

مثال (15-2.10).

- **المعطيات:** فضاء منتهٍ $\Omega = \{x_1, \dots, x_n\}$، أوزان $w_i \geq 0$، $\sum w_i = 1$.
- **المطلوب:** عرّف قياس احتمال منه.
- **الحل:**

١. لكل A: $\mu(A) = \sum_{x_i \in A} w_i$.

٢. $\mu(\Omega) = 1$ والمتطلّبات محقّقة. ■

- **النتيجة:** توزيع احتمالي منفصل عامّ.
- **الربط بالذكاء الاصطناعي:** softmax يُنتج بالضبط هذه الأوزان w_i — «توزيع فئوي» جاهز للتوقّع.

التعريف

dir="ltr"> <div
Definition 1.3.10 (Lebesgue outer measure). For $E \subset \mathbb{R}^d$:

$$m^*(E) = \inf\Big\{ \sum_{k=1}^{\infty} \ell(I_k) : E \subset \bigcup_{k} I_k \Big\},$$

where I_k are d-dimensional intervals, ℓ their volume. E is **Lebesgue measurable** if for every test set A:

$$m^*(A) = m^*(A \cap E) + m^*(A \cap E^c).$$

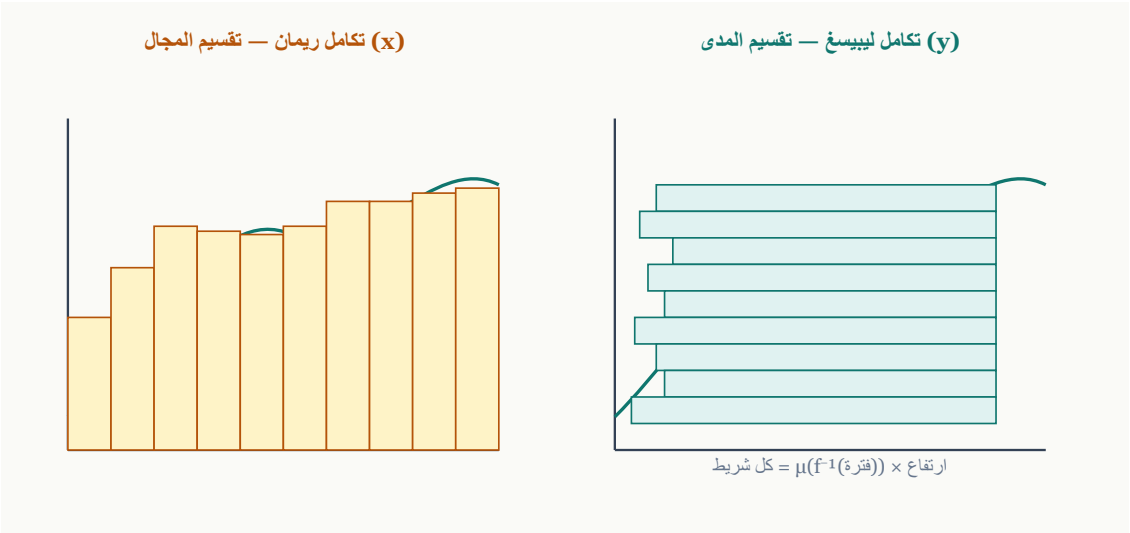
$$m([a,b]) = b - a, \qquad m(\mathbb{Q} \cap [0,1]) = 0. \tag{2.10}$$

النظرية 1.3.10 (خصائص قياس ليبيسغ m):

- **ثبات الترجمة:** $m(E + x) = m(E)$.
- **التجانس:** $m(cE) = |c|^d m(E)$.
- **العدديّة:** للمجموعات المنفصلة $\bigcup E_n$، $m = \sum m(E_n)$.
- **العدّيّة الخارجية:** $m^*(\bigcup E_n) \leq \sum m^*(E_n)$ (لا تطلب منفصلة).

جدول الرموز

الرمز	الاسم	المعنى
$m^*(E)$	القياس الخارجي	أصغر غطاء بمكعّبات
$m(E)$	قياس ليبيسغ	الطول/المساحة/الحجم المعتاد
$\ell(I)$	حجم الفترة	طول/حجم المنطقة I



شكل ٢٠١٠: *
ريمان يقسّم المجال، ليبيسغ يقسّم المدى

رسم توضيحي

<figure> الشكل<figcaption> 2.10: ريمان يقسّم محور x (أشرطة رأسية)؛ ليبيسغ يقسّم محور y (أشرطة أفقية بحسب «مقدار ما قبل الصورة»). هذه الرؤية تسمح بدمج «القفزات» التي تفشل عند ريمان.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«كل مجموعة قابلة للقياس»	توجد مجموعات غير قياسية (فيتالي)	معظم المجموعات العملية قياسية
$m^*(\cup E_n) = \sum m^*(E_n)$ دائماً	العدّية الخارجية متراجحة فقط	تحتاج منفصلة للتساوي
«لأنّ $\mathbb{Q}$ كثيفة» $m(\mathbb{Q}) = 1$	الكثافة لا تعني القياس	$\mathbb{Q}$ عدّية $\Rightarrow$ قياسها 0
الخلط $m([a,b])$ مع $m((a,b))$	كلاهما $b-a$	النقاط بلا قياس

أمثلة محلولة على قياس ليبيسغ (15 مثالاً)

مثال (10.3-1).

- **المعطيات:** $E = [2, 5]$.
- **المطلوب:** $m(E)$.
- **الحل:**

١. من (2.10): الطول $= 5 - 2 = 3$. ■

- **النتيجة:** 3.
- **الربط بالذكاء الاصطناعي:** «عرض نافذة زمنية» في تسلسل بيانات = قياسها؛ أساس تجميع النوافذ.

مثال (3.10-2).

- **المعطيات:** $E = (0,1) \cap \mathbb{Q}$.
- **المطلوب:** $m(E)$.
- **الحل:**

١. $\mathbb{Q}$ عدّية، كل نقطة قياسها 0.

٢. اتحاد عدّي لنقاط $\Rightarrow$ القياس 0. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** مجموعة «كثيفة لكن بلا حجم» — تذكير بأنّ الاحتمال النقطي للمستمرّ صفر رغم كثافة النقاط.

مثال (3.10-3).

- **المعطيات:** مجموعة كانتور C على $[0,1]$.
- **المطلوب:** $m(C)$.
- **الحل:**

١. تُبنى بحذف أثلاث: في الخطوة n نحذف 2^{n-1} فترة طول 3^{-n}.

٢. المحذوف كلّياً: $\sum_{n=1}^{\infty} 2^{n-1}3^{-n} = \frac{1}{3}/(1-\frac{2}{3}) = 1$.

٣. إذن $m(C) = 1 - 1 = 0$ (مع أنّها غير عدّية!). ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «مجموعة لا حجم لها لكن لا تُعدّ» — تحذير رياضي: القياس الصفري لا يلغي الأهمية (مثل مجموعة المعاملات النادرة).

مثال (3.10-4).

- **المعطيات:** $E = [0,1]$، انقلها: $E + 3 = [3,4]$.
- **المطلوب:** $m(E+3)$ (ثبات الترجمة).
- **الحل:**

١. $m(E+3) = m(E) = 1$. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** «إزاحة البيانات» (data shfit) لا تغيّر قياس التوزيع — أساس فرضية i.i.d. تحت الترجمة.

مثال (10.3-5).

- **المعطيات:** $E = (0,1)$، $2E = (0,2)$.
- **المطلوب:** $m(2E)$ (التجانس).
- **الحل:**

١. $m(2E) = |2|^1 \, m(E) = 2$. ■

- **النتيجة:** 2.

- **الربط بالذكاء الاصطناعي:** تغيير مقياس الميزة (scaling) يضرب القياس — سبب تطبيع (normalization) البيانات قبل التدريب.

مثال (10.3-6).

- **المعطيات:** $E_1 = (0,1)$، $E_2 = (1,2)$ (منفصلتان).
- **المطلوب:** $m(E_1 \cup E_2)$.
- **الحل:**

١. منفصلتان $\Longrightarrow$ الجمع العدّي: $1 + 1 = 2$. ■

- **النتيجة:** 2.

- **الربط بالذكاء الاصطناعي:** «اندماج فئتين منفصلتين» لا تداخل $\Longrightarrow$ المساحة مجموع — قاعدة في تقدير كثافة الخليط.

مثال (10.3-7).

- **المعطيات:** $E_n = (0, 1/n)$، $n = 1, 2, \ldots$
- **المطلوب:** $m^*(\bigcup_n E_n)$ بـ العدّيّة الخارجية.
- **الحل:**

١. $\bigcup_n E_n = (0,1)$.

٢. $m^*(\cup E_n) = 1 \leq \sum 1/n = \infty$ (المتراجحة صحيحة). ■

- **النتيجة:** 1 (والمتراجحة تحقّق).

- **الربط بالذكاء الاصطناعي:** «غطاء فضفاض» يعطي حدّاً أعلى — مبدأ الـ bounds covering في تحليل العيّنات.

مثال (10.3-8).

- **المعطيات:** مجموعة كانتور «سمينة» (fat Cantor) بقياس نهائي $1/2$.
- **المطلوب:** بيّن إمكانية $m(C) > 0$ مع عدم فترة.
- **الحل:**

١. احذف أطوالاً مجموعها $1/2$ بدل 1.

٢. الباقي قياسه $1/2 > 0$ ومع ذلك لا يحوي أيّ فترة مفتوحة. ■

- **النتيجة:** قياس موجب بلا فترات.
- **الربط بالذكاء الاصطناعي:** «توزيع بلا كثافة ناعمة لكن بكتلة» — نظير التوزيعات المختلطة (mixed discrete-continuous) في الاحتمال.

مثال (10.3-9).

- **المعطيات:** $E = \mathbb{R} \setminus \mathbb{Q}$ (الأعداد غير النسبية في $[0,1]$).
- **المطلوب:** $m(E \cap [0,1])$.
- **الحل:**

١. $[0,1] = (E \cap [0,1]) \cup (\mathbb{Q} \cap [0,1])$.

٢. القسم العقلاني قياسه $0 \Rightarrow$ الآخر قياسه 1. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** «تقريباً كل نقطة غير نسبية» — لهذا تجاهل القيم النسبية في التكاملات المستمرّة بلا أثر.

مثال (10.3-10).

- **المعطيات:** U مفتوحة في $\mathbb{R}$ = اتحاد فترات مفتوحة (a_k, b_k) منفصلة.
- **المطلوب:** $m(U)$.
- **الحل:**

١. $m(U) = \sum (b_k - a_k)$. ■

- **النتيجة:** مجموع الأطوال.
- **الربط بالذكاء الاصطناعي:** «حجم منطقة الثقة» = مجموع أطوال فترات — خرائط الثقة (confidence regions) في الانحدار.

مثال (11-3.10).

- **المعطيات:** F مغلقة = $\mathbb{R} \setminus U$، U مفتوحة كما بالسابق.
- **المطلوب:** $m(F \cap [0,1])$.
- **الحل:**

١. $1 - m(U) = 1 - \sum(b_k - a_k)$. ■

- **النتيجة:** المتمّم القياسي.
- **الربط بالذكاء الاصطناعي:** «المنطقة الخارجة عن الثقة» تقاس بالمتمّم — خطأ النوع الثاني تحليلياً.

مثال (12-3.10).

- **المعطيات:** $A_n = [0, 1 + 1/n]$.
- **المطلوب:** $m(\bigcap_n A_n)$.
- **الحل:**

١. التقاطع $= [0,1]$.

٢. القياس $= 1$. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** «تقاطع شروط متزايدة الصرامة» يضيّق الحدث إلى النواة — مشابه لـ intersection-over-union في الكشف.

مثال (13-3.10).

- **المعطيات:** E عدّية في $\mathbb{R}^d$ لأيّ d.
- **المطلوب:** $m(E)$.
- **الحل:**

١. كل نقطة قياسها 0؛ اتحاد عدّي $\Longrightarrow$ 0. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** مجموعة المعالم النادرة outliers) منفصلون) بلا «حجم» قياسي — سبب صعوبة تقدير كثافتهم.

مثال (14-3.10).

- **المعطيات:** $m([a,b]) = b-a$ و $[a,b]$ مقابل (a,b) مقابل $(a,b]$.
- **المطلوب:** قارن قياساتها.
- **الحل:**

١. النهايات نقاط قياسها 0، كلها $b-a$. ■

- **النتيجة:** متساوية.
- **الربط بالذكاء الاصطناعي:** «حدود الفترة بلا أثر على التكامل» — لذلك نكتب $\int_a^b$ بلا اهتمام بالنهايات.

مثال (15-3.10).

- **المعطيات:** $m^*(E_1 \cup E_2) \le m^*(E_1) + m^*(E_2)$ مع E_1 قابلة للقياس.
- **المطلوب:** أثبت التراجع باستخدام قابلية القياس.
- **الحل:**

١. $m^*(E_1 \cup E_2) = m^*((E_1 \cup E_2) \cap E_1) + m^*(\cdots \cap E_1^c) = m^*(E_1) + m^*(E_2 \cap E_1^c) \le m^*(E_1) + m^*(E_2)$. ■

- **النتيجة:** متراجحة العدّيّة الخارجية.
- **الربط بالذكاء الاصطناعي:** «الخطأ الكلّي ≤ مجموع الأخطاء» — أساس تحليل تعميم التعلّم الإحصائي (union bound لاحقاً).

التعريف

dir="ltr"> <div
for ffi **measurable** is $f : (X, \mathcal{F}) \to (\mathbb{R}, \mathcal{B})$ **function).** **(Measurable 1.4.10 Definition**
,B set Borel every

$$f^{-1}(B) \in \mathcal{F}.$$

.$a \in \mathbb{R}$ all for $\{x : f(x) > a\} \in \mathcal{F}$ Equivalently
form the has **function simple** A

$$\phi(x) = \sum_{i=1}^{k} a_i \, \mathbf{1}_{A_i}(x), \qquad A_i \in \mathcal{F}. \tag{3.10}$$

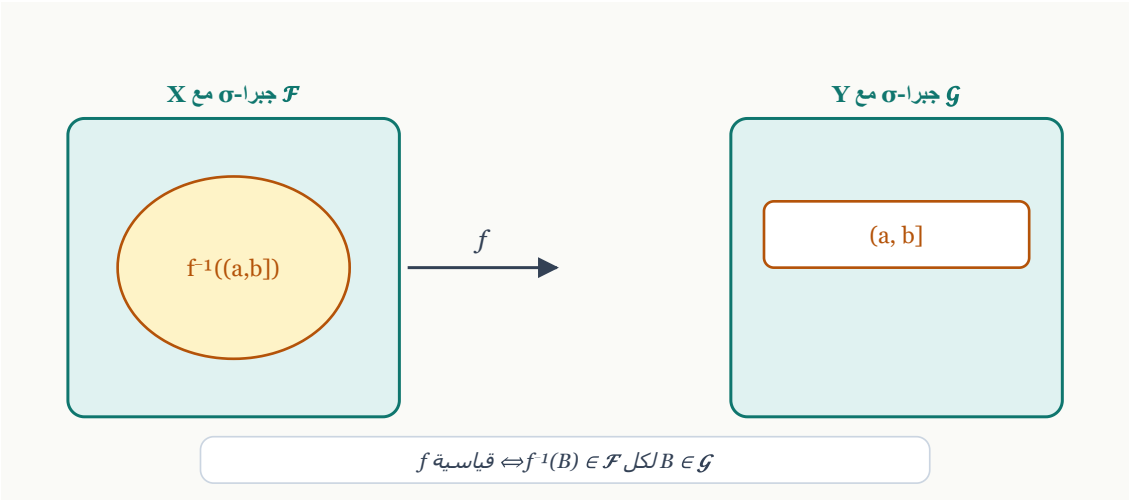
النظرية 1.4.10 (التقريب). كل دالة قياسية غير سالبة = حدّ تصاعدي لدوالّ بسيطة: $0 \le \phi_n \uparrow f$. وكل دالة قياسية عامّة تفاضل إلى $f^+ - f^-$.

جدول الرموز

الرمز	الاسم	المعنى
$f^{-1}(B)$	الصورة العكسية	$\{x : f(x) \in B\}$
$\mathbf{1}_A$	دالة المؤشّر	1 على A و0 خارجها
ϕ	دالة بسيطة	عدد منتهٍ من الخطوات

رسم توضيحي

<figure> الشكل<figcaption>3.10: f قياسية $\iff$ صورة أيّ فترة $(a, b]$ عكسياً تقع في $\mathcal{F}$. الرسم يُظهر $(a, b]$



شكل ٣.١٠: *
الدالة القياسية: صورة كل بوريل عكسياً قياسية

في المستقرّ، وصورتها العكسية (المظلّلة) في الفضاء المصدري يجب أن تكون قياسية.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«القياس على المجال يكفي»	يجب فحص الصورة العكسية	تحقّق $f^{-1}(B) \in \mathcal{F}$
الخلط بين قياس f وقياس المجموعة	f قياسية $\neq \int f$ منتهٍ	القياس شرط، التكامل قيمة
نسيان أنّ الحدّ لدوالّ قياسية قياسي	الحدّ يحافظ القياسيّ	مبرهنة مهمّة للتقارب
اعتبار الدالة البسيطة «تافهة»	كل f تُقرَّب بها	أساس بناء التكامل

أمثلة محلولة على الدوال القياسية (15 مثالاً)

مثال (10.4-1).

- **المعطيات:** $f = \mathbf{1}_A$، $A \in \mathcal{F}$.
- **المطلوب:** هل f قياسية؟
- **الحل:**

١. لـ $t < 0$: $f^{-1}((t, \infty)) = \emptyset$.

٢. لـ $0 \leq t < 1$: A؛ لـ $t \geq 1$: X. كلها في $\mathcal{F}$. ■

- **النتيجة:** نعم — المؤشّر قياسي دائماً لـ A قياسية.
- **الربط بالذكاء الاصطناعي:** «دالة التنشيط الخطوة» في العتبة (threshold) — قياسية، لذا احتمالها معرّف.

مثال (10.4-2).

- **المعطيات:** $f(x) = x$ على $\mathbb{R}$ بوريل.
- **المطلوب:** القياس.
- **الحل:**

١. $\{x : x > a\} = (a, \infty)$ بوريل. ■

- **النتيجة:** قياسية.
- **الربط بالذكاء الاصطناعي:** الميزة المستمرّة قياسية — كل ميزة خام تصلح كـ input للتوقّع.

مثال (10.4-3).

- **المعطيات:** g مستمرّة، f قياسية.
- **المطلوب:** هل $g \circ f$ قياسية؟
- **الحل:**

١. g مستمرّة $\Longrightarrow$ معكوس الفترة مفتوحة؛ $(g \circ f)^{-1}((a, \infty)) = f^{-1}(g^{-1}((a, \infty)))$.

٢. الداخل بوريل $\Longrightarrow$ الخارج قياسي بقياس f. ■

- **النتيجة:** نعم.
- **الربط بالذكاء الاصطناعي:** تطبيق تنشيط مستمرّ (ReLU, sigmoid) على طبقة قياسية يبقيها قياسية — كل مخرجات الشبكة «قياسية».

مثال (10.4-4).

- **المعطيات:** f, g قياسيتان.
- **المطلوب:** هل $\max(f, g)$ قياسية؟
- **الحل:**

١. $\{\max(f, g) > a\} = \{f > a\} \cup \{g > a\} \in \mathcal{F}$. ■

- **النتيجة:** نعم.
- **الربط بالذكاء الاصطناعي:** max-pooling قياسي — عمليات الطبقات التلافيفية تحافظ القياس.

مثال (10.4-5).

- **المعطيات:** $f_n \to f$ نقطةً بنقطة، كل f_n قياسية.
- **المطلوب:** هل f قياسية؟
- **الحل:**

١. $\{f > a\} = \bigcup_{m=1}^{\infty} \bigcup_{N=1}^{\infty} \bigcap_{n \geq N} \{f_n > a + 1/m\}$ قياسي.

٢. اتحادات وتقاطعات عدّية تحفظ $\mathcal{F}$. ■

- **النتيجة:** نعم — الحدّ القياسي قياسي.
- **الربط بالذكاء الاصطناعي:** تقارب شبكة أثناء التدريب يحفظ «قياسية» المخرجات — لا تنشأ قيم غير معرّفة.

مثال (10.4-6).

- **المعطيات:** f قياسية.
- **المطلوب:** هل $|f|$ و f^2 قياسيتان؟
- **الحل:**

١. $|f| > a$ ترجع لفترات على f؛ $f^2 > a$ (=$|f| > \sqrt{a}$) أيضاً. ■

- **النتيجة:** كلاهما قياسي.
- **الربط بالذكاء الاصطناعي:** خسارة MSE تعتمد على f^2 — قياسيتها تضمن أنّ $\mathbb{E}[L]$ معرّف.

مثال (10.4-7).

- **المعطيات:** $\phi(x) = \sum_{i=1}^{3} a_i \mathbf{1}_{A_i}(x)$، A_i منفصلة.
- **المطلوب:** تحقّق أنّها دالة بسيطة.
- **الحل:**

١. مركّبة من 3 مؤشّرات لمنفصلات $\Longrightarrow$ بسيطة بتعريف (10.3). ■

- **النتيجة:** بسيطة.
- **الربط بالذكاء الاصطناعي:** «هيستوغرام» = دالة بسيطة — تقريب أيّ توزيع بعدد منتهٍ من الصناديق.

مثال (4.10-8).

- **المعطيات:** $f(x) = x$ على $[0,1]$، قرّبها بسيطة $\phi_n = \sum_{k=1}^{n} \frac{k-1}{n} \mathbf{1}_{[(k-1)/n,\,k/n)}$.
- **المطلوب:** أثبت $\phi_n \uparrow f$.
- **الحل:**

١. على كل صندوق الخطأ $< 1/n$؛ $\phi_n \le f$ وتتقارب إليها. ■

- **النتيجة:** تقارب من الأسفل.
- **الربط بالذكاء الاصطناعي:** «تكميم الميزة» (quantization) — تقريب المتصل بخطوات، أساس ضغط النماذج.

مثال (4.10-9).

- **المعطيات:** $\mathcal{F} = \{\emptyset, \Omega\}$ تافهة.
- **المطلوب:** ما الدوالّ القياسية؟
- **الحل:**

١. $\{f > a\}$ إمّا $\emptyset$ أو $\Omega \Rightarrow f$ ثابتة. ■

- **النتيجة:** الثوابت فقط.
- **الربط بالذكاء الاصطناعي:** بلا ميزات (σ-جبرا تافهة) لا تعلّم ممكن — نفس استنتاج 12-2.10.

مثال (4.10-10).

- **المعطيات:** $f = \lfloor x \rfloor$ على $\mathbb{R}$.
- **المطلوب:** القياس.
- **الحل:**

١. $\{f > a\} = \bigcup_{k > \lfloor a \rfloor} [k, k+1)$ قياسي. ■

- **النتيجة:** قياسية.
- **الربط بالذكاء الاصطناعي:** التكميم التنازلي (floor) في الترميز الرقمي قياسي — لا يفسد حساب التوقّع.

مثال (4.10-11).

- **المعطيات:** f قياسية، B بوريل.

- **المطلوب:** عرّف توزيع الصورة $\mu_f(B) = \mu(f^{-1}(B))$.
- **الحل:**

١. $f^{-1}(B) \in \mathcal{F} \implies \mu_f$ قياس معرّف جيّداً. ■

- **النتيجة:** قياس الصورة.
- **الربط بالذكاء الاصطناعي:** «توزيع المخرجات» P_Y يحسبها بالضبط — أساس كل توزيع متغيّر عشوائي.

مثال (10.4-12).

- **المعطيات:** $f(x) = e^x$، $g(y) = \ln y$.
- **المطلوب:** هل $g(f(x))$ قياسية؟
- **الحل:**

١. التركيب $x =$ (هوية) قياسية؛ أو عبر مثال 10.4-3. ■

- **النتيجة:** نعم.
- **الربط بالذكاء الاصطناعي:** log-then-exp أو exp-then-log (كـ softmax في log-space) تحافظ القياس — خدعة استقرار عددي من الفصل 6.

مثال (10.4-13).

- **المعطيات:** f قياسية غير سالبة، $\phi_n = \frac{\lfloor 2^n f \rfloor}{2^n} \wedge n$.
- **المطلوب:** بيّن تقريبها من الأسفل.
- **الحل:**

١. كل ϕ_n بسيطة (عدد منتهٍ من القيم)؛ $\phi_n \le f$ وتتقارب. ■

- **النتيجة:** تقارب بسيط من الأسفل.
- **الربط بالذكاء الاصطناعي:** «تقريب التدرّج السفلي» يذكّر بخطوات التعلّم: نقاط منفصلة تتقارب نحو القيمة السلسة.

مثال (10.4-14).

- **المعطيات:** f, g قياسيتان.
- **المطلوب:** هل $f+g$ و fg قياسيتان؟
- **الحل:**

١. $\{f + g > a\}$ يُعبَّر باتحاد عدّي $\{f > q\} \cap \{g > a - q\}$ (عقلات q).

٢. fg عبر $f^2, g^2, (f+g)^2$. ■

- **النتيجة:** نعم لكلّ العمليات الجبرية.

- **الربط بالذكاء الاصطناعي:** أيّ تعبير حسابي على مخرجات الشبكة يبقى قياسياً — لا يخرج عن فضاء الاحتمال.

مثال (4.10-15).

- **المعطيات:** $f = \mathbf{1}_{\mathbb{Q}}$ (ديريكليه).

- **المطلوب:** هل قياسية على $(\mathbb{R}, \mathcal{B})$؟

- **الحل:**

١. $\{f > 1/2\} = \mathbb{Q} \in \mathcal{B}$ (عدّية $\Longrightarrow$ بوريل).

٢. إذن قياسية (رغم كونها «مضطربة»). ■

- **النتيجة:** قياسية.

- **الربط بالذكاء الاصطناعي:** «دالة مضطربة لكن قياسية» — التكامل اللاحق سيعطيها قيمة منطقية (صفر تقريباً) رغم شكلها.

التعريف

dir="ltr"> <div
Definition 1.5.10 (Lebesgue integral). For a simple $\phi = \sum a_i \mathbf{1}_{A_i} \geq 0$:

$$\int \phi \, d\mu = \sum_{i} a_i \, \mu(A_i).$$

For $f \geq 0$: $\int f \, d\mu = \sup \left\{ \int \phi \, d\mu : \ 0 \leq \phi \leq f, \ \phi \text{simple} \right\}$. For general $f = f^+ - f^-$ with $\int |f| d\mu < \infty$: $\int f = \int f^+ - \int f^-$.

$$\int_X (af + bg) \, d\mu = a \int_X f \, d\mu + b \int_X g \, d\mu. \tag{4.10}$$

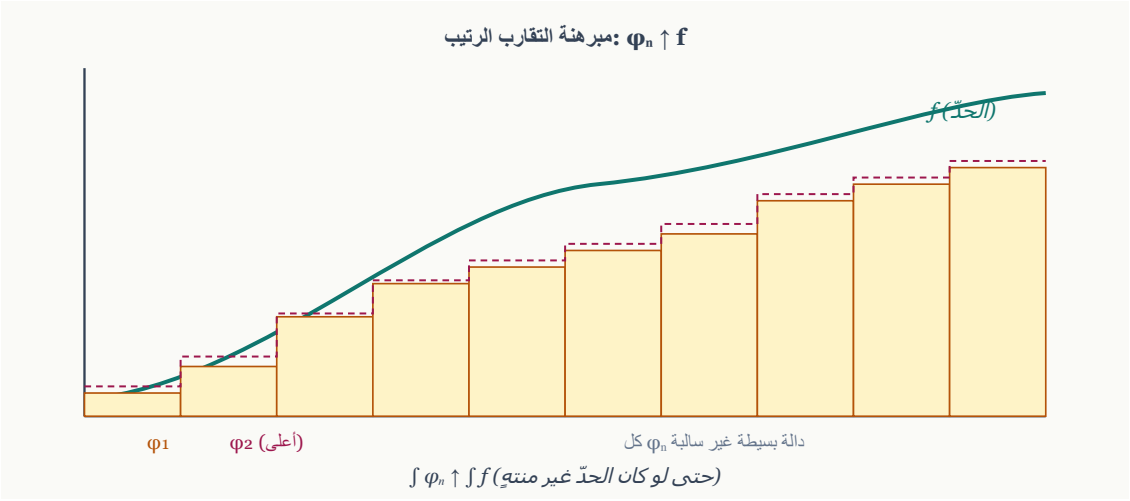
النظرية 1.5.10 (التكافؤ عدّ النقاط). لـ $f \geq 0$ قياسية و $\{x : f(x) > 0\}$ عدّية، $\int f \, d\mu = \sum_x f(x)\mu(\{x\})$.

جدول الرموز

الرمز	الاسم	المعنى
$\int f \, d\mu$	تكامل ليبيسغ	«متوسّط مرجّح بـ μ»
f^+, f^-	الأجزاء الموجبة/السالبة	$\max(f, 0), \max(-f, 0)$
$\int \lvert f \rvert d\mu < \infty$	قابلية التكامل	شرط الاندماج

رسم توضيحي

<figure> الشكل<figcaption> 4.10: نبني $\int f$ كـ sup على الدوالّ البسيطة $\phi_n \uparrow f$. الأشرطة (أسفل) ترتفع نحو



شكل ٤.٠١٠: *
التكامل كحدّ لأعلى دوالّ بسيطة

منحنى f (أعلى)؛ مساحتها تتقارب من الأسفل.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الخلط بين $\int f\,d\mu$ و $\int f(x)dx$	$d\mu$ قياس عامّ	اكتب القياس صراحة
«التكامل يوجد دائماً»	قد يكون ∞	افحص $\int \lvert f\rvert < \infty$
اعتبار ديريكليه «غير قابلة للتكامل»	قابلة لكن قيمتها 0	ليبيسغ يتعامل معها
نسيان أنّ $\int f = \int f^+ - \int f^-$ يحتاج اندماجاً	قد يخرج $\infty - \infty$	اشترط $\int \lvert f\rvert < \infty$

أمثلة محلولة على تكامل ليبيسغ (15 مثالاً)

مثال (1-5.10).

- **المعطيات:** $f = \mathbf{1}_A$، $\mu(A) = 0.3$.
- **المطلوب:** $\int f\,d\mu$.
- **الحل:**

١. $\int \mathbf{1}_A\,d\mu = \mu(A) = 0.3$. ■

- **النتيجة:** 0.3.
- **الربط بالذكاء الاصطناعي:** «احتمال حدث» = تكامل مؤشّره — التعريف الموحّد للتوقّع.

مثال (5.10-2).

- **المعطيات:** $f = c$ (ثابتة) على A، $\mu(A) = 5$.
- **المطلوب:** $\int_A c \, d\mu$.
- **الحل:**
١. $c \int_A 1 \, d\mu = c\,\mu(A) = 5c$. ■
- **النتيجة:** $5c$.
- **الربط بالذكاء الاصطناعي:** «متوسّط ثابت على منطقة» = القيمة × المساحة — كتلة unfiorm.

مثال (5.10-3).

- **المعطيات:** $\phi = 2\mathbf{1}_{A_1} + 5\mathbf{1}_{A_2}$، $\mu(A_1) = 1, \mu(A_2) = 2$ منفصلتان.
- **المطلوب:** التكامل.
- **الحل:**
١. $2 \cdot 1 + 5 \cdot 2 = 12$. ■
- **النتيجة:** 12.
- **الربط بالذكاء الاصطناعي:** «قيمة متدرّجة لخطوات» — أساس حساب reward expected في التعزيزي.

مثال (5.10-4).

- **المعطيات:** $f(x) = x$ على $[0,1]$ بـ ليبيسغ.
- **المطلوب:** $\int_0^1 x \, dx$ (ليبيسغ).
- **الحل:**
١. بالتقريب البسيط: مساحة المثلث $= 1/2$. ■
- **النتيجة:** $1/2$.
- **الربط بالذكاء الاصطناعي:** «المتوسّط على unfiorm» = 1/2 — معيار مقارنة كل التوزيعات.

مثال (5.10-5).

- **المعطيات:** $f = \mathbf{1}_{\mathbb{Q}}$ (ديريكليه) على $[0,1]$.
- **المطلوب:** $\int_0^1 f \, dx$ ليبيسغ مقابل ريمان.

- **الحل:**

١. ليبيسغ: $\int \mathbf{1}_{\mathbb{Q}} = m(\mathbb{Q}) = 0$.

٢. ريمان: غير موجود (الأعلى 1، الأسفل 0). ■

- **النتيجة:** 0 لليبيسغ؛ ريمان يفشل.

- **الربط بالذكاء الاصطناعي:** «دالة مضطربة لكن متكاملة» — ليبيسغ يمنحنا توقّعاً منطقياً حيث يفشل ريمان.

مثال (10.5-6).

- **المعطيات:** $f = \sum_{k=1}^{\infty} 2^{-k}\mathbf{1}_{\{x_k\}}$ على فضاء منفصل.

- **المطلوب:** $\int f\, d\mu$ (عدّ النقاط).

- **الحل:**

١. النظرية 10.5.1: $\sum_k 2^{-k}\mu(\{x_k\}) = \sum_k 2^{-k} = 1$. ■

- **النتيجة:** 1.

- **الربط بالذكاء الاصطناعي:** «توزيع كثافته نقطية» = مجموع الأوزان — softmax النهائي يُدمج هكذا.

مثال (10.5-7).

- **المعطيات:** $\mu =$ unfiorm على $[0,1]$، $f(x) = e^x$.

- **المطلوب:** $\int_0^1 e^x\, dx$.

- **الحل:**

١. $e^1 - e^0 = e - 1 \approx 1.718$. ■

- **النتيجة:** $e - 1$.

- **الربط بالذكاء الاصطناعي:** «متوسّط دالة أُسّية» — يظهر في توقّع log-likelihood المُسجّل.

مثال (10.5-8).

- **المعطيات:** f, g قابلتا التكامل، $a, b \in \mathbb{R}$.

- **المطلوب:** أثبت الخطيّة (10.4).

- **الحل:**

١. للبسيط: $\int (a\phi + b\psi) = a\sum a_i\mu + b\sum b_i\mu$.

٢. الانتقال للحدّ الأعلى يحفظ الخطيّة. ■

- **النتيجة:** (10.4) محقّقة.

- **الربط بالذكاء الاصطناعي:** «الخسارة الكلّية = مجموع الخسارات» — خطيّة التكامل تبرّر جمع الخسائر على العيّنات.

مثال (10.5-9).

- **المعطيات:** $f \geq 0$، $A \subset B$.
- **المطلوب:** $\int_A f \leq \int_B f$.
- **الحل:**

١. $f\mathbf{1}_A \leq f\mathbf{1}_B \implies$ بالتعريف الأعلى الحدّ أصغر. ■

- **النتيجة:** أحاديّة التوتّر.
- **الربط بالذكاء الاصطناعي:** «خسارة على مجموعة فرعية $\leq$ الكلّية» — أساس تحليل الأخطاء حسب الشريحة.

مثال (10.5-10).

- **المعطيات:** $f = 0$ «تقريباً كل مكان» (a.e.)، أي خارج مجموعة قياسها 0.
- **المطلوب:** $\int f \, d\mu$.
- **الحل:**

١. نعدّل على مجموعة قياس 0 لا تؤثّر في التكامل $\implies$ 0. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «اختلاف على عيّنات معدودة لا يغيّر التوقّع» — سبب إهمال الضجيج النقطي في التقييم.

مثال (10.5-11).

- **المعطيات:** $f(x) = |x|$ على $[-1, 1]$.
- **المطلوب:** التكامل.
- **الحل:**

١. زوجي: $2 \int_0^1 x \, dx = 2 \cdot \frac{1}{2} = 1$. ■

- **النتيجة:** 1.
- **الربط بالذكاء الاصطناعي:** «متوسّط القيمة المطلقة» (L1) حول الصفر) — يقابل loss. MAE

مثال (10.5-12).

- **المعطيات:** $f_n = \mathbf{1}_{[0,1/n]}$ على $[0,1]$.
- **المطلوب:** $\int f_n$ و $\lim$ منها.
- **الحل:**

١. $\int f_n = 1/n \to 0$.

٢. النقطة-الحدّ $f_n \to 0$ a.e. $\Longrightarrow$ التكامل يتبع. ■

- **النتيجة:** يصغر إلى 0.
- **الربط بالذكاء الاصطناعي:** «ذيول تتلاشى» — خطأ الذيل $0 \to$ يعني تقارب التقدير.

مثال (10.5-13).

- **المعطيات:** μ احتمال، $0 \le f \le 1$.
- **المطلوب:** حدود $\int f\,d\mu$.
- **الحل:**

١. $0 \le \int f \le \int 1 = 1$. ■

- **النتيجة:** في $[0,1]$.
- **الربط بالذكاء الاصطناعي:** «دقّة نموذج» بين 0 و1 — المتوسّط (التوقّع) داخل نفس الحد.

مثال (10.5-14).

- **المعطيات:** $f(x) = x^2$ على $[0,1]$، قرّبها بسيطة بـ $n = 4$.
- **المطلوب:** قدّر $\int_0^1 x^2 dx$ بالتقريب السفلي.
- **الحل:**

١. صناديق $[0,.25), [.25,.5), \ldots$ قيم سفلية $0, .0625, .25, .5625 \times 25.0 \Longrightarrow$ مجموع 0.21875.

٢. الحقيقي $1/3 \approx 0.333$ (التقريب من الأسفل). ■

- **النتيجة:** 0.219 كحدّ أدنى.
- **الربط بالذكاء الاصطناعي:** «تقدير Carlo Monte سفلي» — أخذ عيّنات يعطي حدوداً أدنى تقارب القيمة.

مثال (10.5-15).

- **المعطيات:** f قابلة للتكامل، $\int |f| = 0$.

- **المطلوب:** استنتج $f = 0$ a.e.
- **الحل:**

١. لو $f \neq 0$ على مجموعة قياس > 0 لكان $\int |f| > 0$.

٢. إذن $f = 0$ a.e. ■

- **النتيجة:** التكامل الصفري $\Longrightarrow$ الانعدام تقريباً كل مكان.
- **الربط بالذكاء الاصطناعي:** «خسارة 0 على التوزيع $\Longrightarrow$ نموذج مثالي» — لكن فقط a.e. (قد يخطئ على مجموعة نادرة).

النظريات

dir="ltr"> <div

Theorem 1.6.10 (Monotone Convergence — MCT). If $0 \le f_1 \le f_2 \le \cdots$ and $f_n \to f$ then a.e.,

$$\lim_{n\to\infty} \int f_n \, d\mu = \int f \, d\mu.$$

Theorem 2.6.10 (Fatou's Lemma). For any sequence $f_n \ge 0$:

$$\int \liminf_n f_n \, d\mu \le \liminf_n \int f_n \, d\mu.$$

Theorem 3.6.10 (Dominated Convergence — DCT). If $|f_n| \le g$ and a.e. $f_n \to f$ with $\int g \, d\mu < \infty$ then

$$\lim_{n\to\infty} \int f_n \, d\mu = \int f \, d\mu.$$

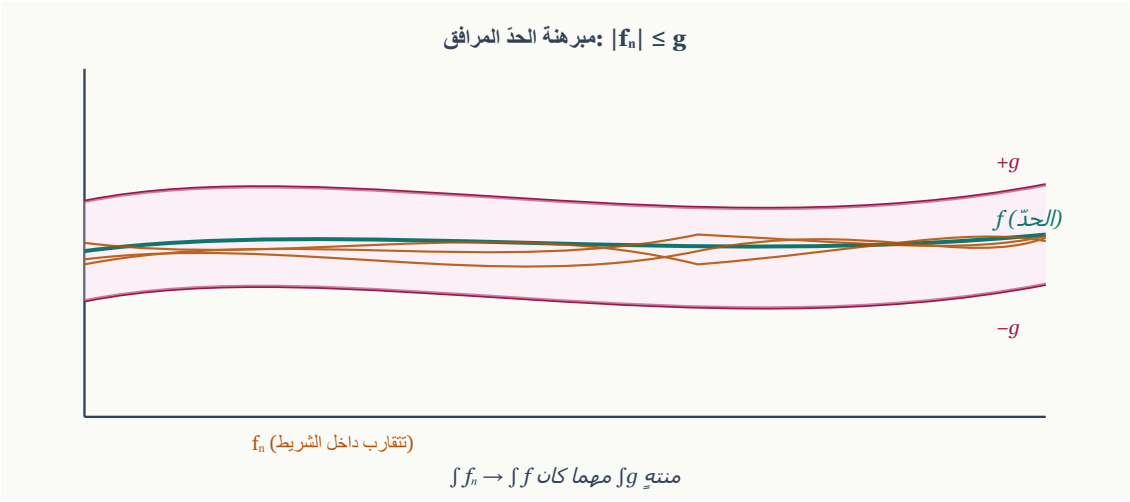
$$\text{DCT: } |f_n| \le g,\ \int g < \infty \implies \int f_n \to \int f. \tag{5.10}$$

جدول الرموز

الرمز	الاسم	المعنى
$f_n \uparrow f$	تقارب رتيب	غير ناقصة نحو f
$\liminf$	الحدّ الأدنى	$\sup_n \inf_{k \ge n}$
g المرافق	دالة الإخضاع	تُغلِّف كل f_n

رسم توضيحي

<figure> الشكل<figcaption> 5.10: مبرهنة الحدّ المرافق — كل f_n محصورة داخل الشريط $[-g, g]$. الحصار بقياس منتهٍ يضمن أنّ تقارب الدوالّ يورث تقارب التكاملات.</figcaption> </figure>



شكل ٥.١٠: *
التقارب المرافق: تسلسل محصور بين ±g

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«الحدّ والتكامل يُتبادلان دائمًا»	بلا شرط ينهار (مثال التنوء المتحرك)	استخدم MCT/DCT
نسيان شرط الإخضاع في DCT	التسلسل قد «يهرب للا نهاية»	$\int g < \infty$ بـ $\lvert f_n \rvert \le g$
Fatou تعطي مساواة	تُعطي فقط $\le$	متراجحة أحاديّة الاتجاه
MCT للدوالّ الموقّعة	تتطلّب غير سالبة	افصل f^+, f^-

أمثلة محلولة على مبرهنات التقارب (15 مثالاً)

مثال (10.6-1).

- **المعطيات:** $\phi_n = \sum_{k=1}^{n} \frac{k-1}{n} \mathbf{1}_{[(k-1)/n,\,k/n)}$ تقارب $f(x) = x$ على $[0,1]$.
- **المطلوب:** استخدم MCT لحساب $\int_0^1 x\,dx$.
- **الحل:**

١. $\phi_n \uparrow x$ غير سالبة.

٢. $\int \phi_n = \frac{n+1}{2n} - \frac{1}{2} \to \frac{1}{2}$. ■

- **النتيجة:** $1/2$.
- **الربط بالذكاء الاصطناعي:** «بناء التوقّع تدريجياً» = MCT — أساس value expected التراكمي.

مثال (10.6-2).

- **المعطيات:** $f_n = n\mathbf{1}_{(0,1/n)}$ على $[0,1]$.

- **المطلوب:** هل ينطبق DCT؟ وما $\lim \int f_n$؟
- **الحل:**

١. $\int f_n = 1$ لكل n لكن $f_n \to 0$ a.e.

٢. لا دالة g منتهية تُغلّفها (الذروة $\to \infty$) $\Longrightarrow$ DCT لا ينطبق. ■

- **النتيجة:** الحدّ 0 لكن التكاملات 1 — لا تبادل.
- **الربط بالذكاء الاصطناعي:** «نتوء متحرك» — تحذير: تبادل الحدّ/التكامل بلا إخضاع يفسد اشتقاق التوقّعات.

مثال (10.6-3).

- **المعطيات:** $f_n(x) = x^n$ على $[0,1]$.
- **المطلوب:** $\lim \int_0^1 x^n dx$ بـ DCT؟
- **الحل:**

١. $|x^n| \le 1$ على $[0,1]$ (قياس 1 منتهٍ) $\Longrightarrow$ DCT.

٢. الحدّ $0 = \mathbf{1}_{\{1\}}$ a.e. $\Longrightarrow$ التكامل $\to 0$. (فعلياً $1/(n+1) \to 0$). ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «تآكل الاحتمال نحو الحافة» — مشابه لتوزّع يتركّز عند نقطة.

مثال (10.6-4).

- **المعطيات:** $f_n = \mathbf{1}_{(n,n+1)}$ على $\mathbb{R}$ بـ ليبيسغ.
- **المطلوب:** Fatou عليها.
- **الحل:**

١. $\liminf f_n = 0$ (كل نقطة خارج كل النطاقات لتكن كبيرة).

٢. $\int f_n = 1 \Longrightarrow 0 \le \liminf 1 = 1$ — Fatou محقّقة بـ $\le$. ■

- **النتيجة:** متراجحة لا مساواة.
- **الربط بالذكاء الاصطناعي:** «كتلة تهاجر للا نهاية» — تذكير أنّ التكاملات قد لا تتقارب رغم صغر كل دالة موضعياً.

مثال (10.6-5).

- **المعطيات:** $f_n \to f$ بلا إخضاع لكن على فضاء قياسه منتهٍ و $|f_n| \le M$.
- **المطلوب:** استنتج DCT مبسّطة.
- **الحل:**

١. $g = M$ ثابتة، $\int g = M\mu(X) < \infty$.

٢. DCT ينطبق. ■

- **النتيجة:** التبادل مضمون.
- **الربط بالذكاء الاصطناعي:** «مخرجات محصورة + بيانات منتهية» ⟹ تبادل آمن — أساس bounded convergence في الشبكات.

مثال (10.6-6).

- **المعطيات:** أعمدة $a_n \ge 0$، $\sum_{n=1}^{\infty} a_n$.
- **المطلوب:** اشتقّ رؤية سلسلة كتكامل عدّي.
- **الحل:**

١. $f_n = \sum_{k=1}^{n} a_k \mathbf{1}_{\{k\}}$، $\uparrow \sum a_k$.

٢. MCT: $\int f_n = \sum_{k=1}^{n} a_k \to \sum a_k$. ■

- **النتيجة:** جمع السلسلة = تكامل.
- **الربط بالذكاء الاصطناعي:** «مجموع خسائر العيّنات = توقّع» — جسر MCT بين السلسلة والتوقّع.

مثال (10.6-7).

- **المعطيات:** f_n تقارب f في L^1: $\int |f_n - f| \to 0$.
- **المطلوب:** استنتج $\int f_n \to \int f$.
- **الحل:**

١. $\left|\int f_n - \int f\right| \le \int |f_n - f| \to 0$. ■

- **النتيجة:** تقارب L^1 يورث تقارب التكامل.
- **الربط بالذكاء الاصطناعي:** «خسارة التدريب تتقارب» (L^1) ⟹ توقّعات التوزيع تتقارب — قياس تقارب المُقدِّر.

مثال (10.6-8).

- **المعطيات:** $f_n(x) = \frac{\sin(nx)}{n}$ على $[0,1]$.
- **المطلوب:** $\lim \int_0^1 f_n$.
- **الحل:**

١. $|f_n| \le 1/n \le 1$، الحدّ 0.

٢. DCT $\Longrightarrow$ التكامل $\to 0$. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «تردّدات سريعة تختفي في التكامل» — مبدأ التذبذب في التحليل الطيفي.

مثال (10.6-9).

- **المعطيات:** $f_n = e^{-nx}$ على $[0,1]$.
- **المطلوب:** $\lim \int_0^1 e^{-nx}dx$.
- **الحل:**

١. لـ $x > 0$: $e^{-nx} \to 0$؛ عند $x = 0$: الحدّ = 1. a.e. $= \mathbf{1}_{\{0\}}$

٢. $|f_n| \le 1 \Longrightarrow$ DCT $\Longrightarrow$ التكامل $\to 0$. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «تلاشٍ أسيّ» — نواة حرارية (dffiusion kernel) تتقارب نحو دلتا، وهنا نحو الصفر.

مثال (10.6-10).

- **المعطيات:** $X_n \to X$ احتمالياً، $|X_n| \le Y$ بـ $\mathbb{E}[Y] < \infty$.
- **المطلوب:** أثبت $\mathbb{E}[X_n] \to \mathbb{E}[X]$.
- **الحل:**

١. هذا DCT بالقياس الاحتمالي (10.5).

٢. $\mathbb{E}[X_n] = \int X_n d\mathbb{P} \to \int X d\mathbb{P} = \mathbb{E}[X]$. ■

- **النتيجة:** تقارب التوقّعات.
- **الربط بالذكاء الاصطناعي:** «نموذج يتقارب احتمالياً + محدود القيمة» $\Longrightarrow$ توقّع خسارته يتقارب — شرط تحليل التعميم.

مثال (10.6-11).

- **المعطيات:** $f_n = \min(f, n)$ لـ $f \geq 0$.
- **المطلوب:** استخدم MCT لإثبات $\int f = \lim \int \min(f, n)$.
- **الحل:**

١. $\min(f, n) \uparrow f$ غير سالبة.

٢. MCT مباشرة. ■

- **النتيجة:** تقارب من الأسفل.

- **الربط بالذكاء الاصطناعي:** «قص القيم المتطرفة تدريجياً» (clipping) يقرّب التكامل الأصلي — clipping في الخسائر.

مثال (10.6-12).

- **المعطيات:** $f_n = n^2 x(1-x)^n$ على $[0, 1]$.
- **المطلوب:** هل $\int f_n \to \int \lim f_n$؟
- **الحل:**

١. الحدّ النقطي 0؛ لكن $\int f_n = n^2 \cdot \frac{1}{(n+1)(n+2)} \to 1 \neq 0$.

٢. لا إخضاع $\Longrightarrow$ DCT لا ينطبق. ■

- **النتيجة:** لا تبادل (مثال مضادّ).

- **الربط بالذكاء الاصطناعي:** حتى مع «اختفاء نقطي» قد يبقى تكامل متبقّ — حذر في اشتقاق التوقّعات التبادلية.

مثال (10.6-13).

- **المعطيات:** سلسلة دوالّ $f_n \geq 0$ بـ $\int f_n \leq C$.
- **المطلوب:** نتيجة Fatou.
- **الحل:**

١. $\int \liminf f_n \leq \liminf \int f_n \leq C$. ■

- **النتيجة:** الحدّ الأدنى محصور.

- **الربط بالذكاء الاصطناعي:** «الخسارة الكلّية محدودة» $\Longrightarrow$ الحدّ الأدنى للخسارة محدود — ضمان عدم انفجار التدريب.

مثال (10.6-14).

- **المعطيات:** $f_n(x) = \frac{n}{1+n^2x^2}$ (نواة بواسون) على $\mathbb{R}$.
- **المطلوب:** سلوك $\int_{-\infty}^{\infty} f_n dx$.
- **الحل:**

١. بتعويض $u = nx$: التكامل $= \int \frac{1}{1+u^2} du = \pi$ لكل n (ثابت!).

٢. الحدّ النقطي 0 لكن التكامل $\pi \Longrightarrow$ لا DCT (لا إخضاع منتهٍ). ■

- **النتيجة:** تقارب ضعيف نحو دلتا ديراك (كتلة بلا عرض).
- **الربط بالذكاء الاصطناعي:** «نواة تقارب نحو delta» — أساس الـ reparameterization والتوزيعات الانتقالية في dffiusion.

مثال (10.6-15).

- **المعطيات:** توزيع احتمالي $P_n \to P$ بالتقارب الضعيف، دالة h مستمرّة محدودة.
- **المطلوب:** استنتج $\int h\, dP_n \to \int h\, dP$.
- **الحل:**

١. h محدودة $\Longrightarrow$ إخضاع بثابت؛ تعريف/DCT التقارب الضعيف.

٢. $\mathbb{E}_{P_n}[h] \to \mathbb{E}_P[h]$. ■

- **النتيجة:** تقارب التوقّعات.
- **الربط بالذكاء الاصطناعي:** «توزيع المخرجات يتقارب $\Longrightarrow$ مقاييسها تتقارب» — أساس تقييم نموذج توليدي (FID يستخدم توقّعات).

التعريف

dir="ltr"> <div

Definition 10.7.1 (Lebesgue–Stieltjes integral). Let $F : \mathbb{R} \to \mathbb{R}$ be increasing and right-continuous. It defines a measure μ_F by

$$\mu_F\big((a, b]\big) = F(b) - F(a).$$

The **Lebesgue–Stieltjes integral** of h is

$$\int h(x)\, dF(x) := \int h(x)\, d\mu_F(x).$$

function, step a is F fi ;$dF = F'(x)dx$ continuous, absolutely is F If

$$\int h\,dF = \sum_i h(x_i)\,\Delta F_i, \quad \Delta F_i = F(x_i) - F(x_i^-).$$

$$\int h\,dF = \sum_i h(x_i)\Delta F_i \text{ (discrete)}, \qquad \int h(x)F'(x)\,dx \text{ (smooth)}. \tag{6.10}$$

النظرية 1.7.10 (خصائص):

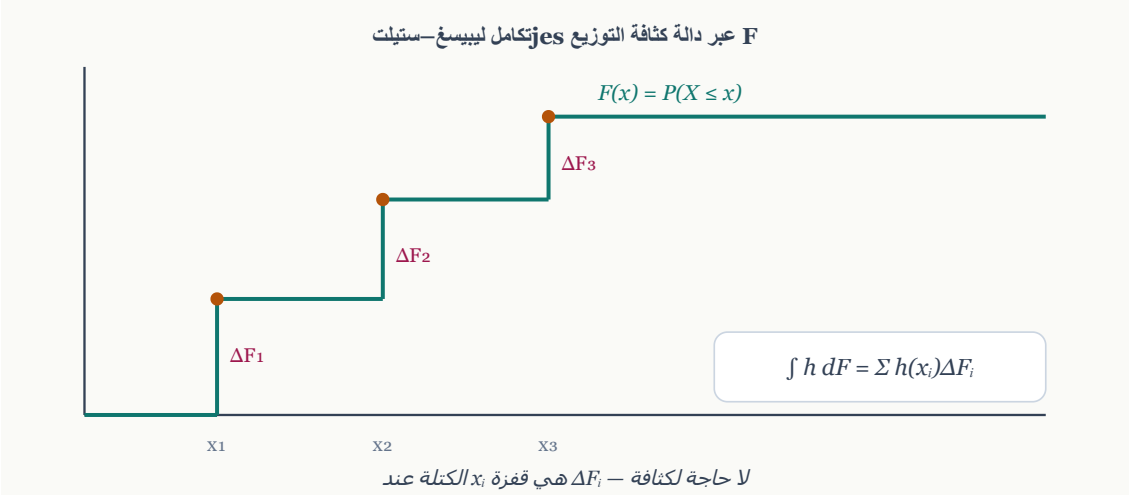
- **الخطيّة:** $\int (ah + bg)dF = a\int h\,dF + b\int g\,dF$.
- **التكامل بالأجزاء:** $\int_a^b h\,dF = h(b)F(b) - h(a)F(a) - \int_a^b F\,dh$.
- **دلتا ديراك:** إذا F قفزة عند c فقط، $\int h\,dF = h(c)$.

جدول الرموز

الرمز	الاسم	المعنى
F	دالة كثافة التوزيع (CDF)	$F(x) = P(X \le x)$
μ_F	القياس المرافق	كتلته = قفزات F
dF	الإجراء (measure element)	$F'(x)dx$ أو $\sum \Delta F_i \delta_{x_i}$

رسم توضيحي

<figure> الشكل<figcaption>6.10: $F(x) = P(X \le x)$ دالة صاعدة؛ تكامل h بالنسبة لـ dF هو مجموع $h(x_i)$



شكل ٦.١٠: *
تكامل ستيلتjes ككتل عند قفزات CDF

مضروباً في ارتفاع القفزة ΔF_i عند كل نقطة. لا حاجة لكثافة — يعمل للتوزيعات المختلطة.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الخلط dF مع $F\,dx$	dF إجراء لا دالة	اكتب القياس صراحة
نسيان القفزات في المنفصل	المرء يدمج فقط الكثافة	أضف $\sum h(x_i)\Delta F_i$
«Stieltjes = ريمان-ستيلتjes فقط»	ليبيسغ-ستيلتjes أعمّ	التكامل على μ_F
تجاهل الاستمرار يميناً	شرط تعريف القياس	F يمين-مستمرة دائماً

أمثلة محلولة على تكامل ليبيسغ–ستيلتjes (15 مثالاً)

مثال (10.7-1).

- **المعطيات:** $F(x) = \mathbf{1}_{[0,\infty)}(x)$ (قفزة عند 0 بارتفاع 1).
- **المطلوب:** $\int h\,dF$.
- **الحل:**

١. $\Delta F_0 = 1$ عند $x = 0$، باقي الصفر.

٢. $\int h\,dF = h(0)$. ■

- **النتيجة:** $h(0)$ — دلتا ديراك.
- **الربط بالذكاء الاصطناعي:** «توزيع منفصل عند نقطة» = دلتا — يظهر في الأهداف الحتمية (hard labels).

مثال (10.7-2).

- **المعطيات:** $F(x) = x$ على $[0,1]$ (unfiorm).
- **المطلوب:** $\int_0^1 x\,dF(x)$.
- **الحل:**

١. $F'(x) = 1 \Longrightarrow \int_0^1 x \cdot 1\,dx = 1/2$. ■

- **النتيجة:** $\mathbb{E}[X] = 1/2$ لـ unfiorm.
- **الربط بالذكاء الاصطناعي:** «التوقّع تحت unfiorm — معيار المقارنة لأيّ توزيع.

مثال (10.7-3).

- **المعطيات:** X بقيم $\{1,2,3\}$ واحتمالات $0.2, 0.3, 0.5$.
- **المطلوب:** $\mathbb{E}[X] = \int x\,dF$.
- **الحل:**

١. $\Delta F_1 = 0.2, \Delta F_2 = 0.3, \Delta F_3 = 0.5$.

٢. $1(0.2) + 2(0.3) + 3(0.5) = 0.2 + 0.6 + 1.5 = 2.3$. ■

- **النتيجة:** 2.3.
- **الربط بالذكاء الاصطناعي:** «توقّع منفصل» = مجموع قيم×احتمالات — تماماً ما يحسبه softmax×logits.

مثال (10.7-4).

- **المعطيات:** $F(x) = 1 - e^{-\lambda x}$ لـ $x \geq 0$ (أسّي).
- **المطلوب:** $\mathbb{E}[X] = \int x\, dF$.
- **الحل:**

١. $F'(x) = \lambda e^{-\lambda x}$.

٢. $\int_0^\infty x\lambda e^{-\lambda x} dx = 1/\lambda$. ■

- **النتيجة:** $1/\lambda$.
- **الربط بالذكاء الاصطناعي:** «المتوسّط الأسّي» — يظهر في أوقات الخدمة/الانتظار ومعدّلات التعرّف.

مثال (10.7-5).

- **المعطيات:** F تقفز عند $x_1 = 0$ (0.5) و $x_2 = 1$ (0.5).
- **المطلوب:** $\int x^2\, dF$.
- **الحل:**

١. $0^2(0.5) + 1^2(0.5) = 0.5$. ■

- **النتيجة:** 0.5.
- **الربط بالذكاء الاصطناعي:** «توزيع مزدوج النقاط» — نموذج لـ mixture of two outcomes.

مثال (10.7-6).

- **المعطيات:** $h(x) = e^{tx}$، F توزيع X.
- **المطلوب:** عرّف الدالة المولّدة للحظة $M(t) = \int e^{tx} dF$.
- **الحل:**

١. $M(t) = \mathbb{E}[e^{tX}]$ — تحوّل لابلاس.

٢. مشتقّتها عند 0 تعطي اللحظات. ■

- **النتيجة:** $M(t)$ العامل المولّد.
- **الربط بالذكاء الاصطناعي:** «اللحظات عبر التفاضل» — أساس تقدير إحصاء اللحظات وتنظيم التوزيعات.

مثال (10.7-7).

- **المعطيات:** توزيع مختلط: كتلة 0.7 عند 0 و unfiorm على $(0,1)$ بكتلة 0.3.
- **المطلوب:** $\mathbb{E}[X]$ بـ Stieltjes.
- **الحل:**

١. القفزة: $0 \cdot 0.7 = 0$؛ المستمرّ: $0.3 \int_0^1 x\,dx = 0.3(0.5) = 0.15$.

٢. المجموع 0.15. ■

- **النتيجة:** 0.15.
- **الربط بالذكاء الاصطناعي:** «توزيع مختلط» discrete-continuous — تماماً ما يصف بيانات بقيم مفقودة عند الصفر + مستمرّ.

مثال (10.7-8).

- **المعطيات:** F تقفز بـ $\Delta F_i = 1/n$ عند كل نقطة بيانات x_i (التوزيع التجريبي).
- **المطلوب:** $\int h\,dF_n$ (المتوسّط التجريبي).
- **الحل:**

١. $\sum_i h(x_i) \cdot \frac{1}{n} = \frac{1}{n}\sum h(x_i)$. ■

- **النتيجة:** متوسّط العيّنات.
- **الربط بالذكاء الاصطناعي:** «التوقّع التجريبي = متوسّط العيّنات» — الجسر بين loss train و risk، expected.

مثال (10.7-9).

- **المعطيات:** $\int_a^b h\,dF$ مع F يمين-مستمرة.
- **المطلوب:** صيغة التكامل بالأجزاء (النظرية 10.7.1).
- **الحل:**

١. $\int_a^b h\,dF = h(b)F(b) - h(a)F(a) - \int_a^b F\,dh$. ■

- **النتيجة:** صيغة Stieltjes.
- **الربط بالذكاء الاصطناعي:** «تبادل التكامل» هذا يُستخدم في اشتقاق ELBO وتحليل التباين.

مثال (10-7.10).

- **المعطيات:** $F(x) = \Phi(x)$ (توزيع طبيعي معياري).
- **المطلوب:** $\int x \, d\Phi(x)$.
- **الحل:**

١. الكثافة $\phi(x)$ متماثلة حول 0.

٢. $\int x\phi(x)dx = 0$. ■

- **النتيجة:** 0.
- **الربط بالذكاء الاصطناعي:** «توقّع التوزيع المتناظر = 0» — مركزية الـ Gaussian حول mean.

مثال (11-7.10).

- **المعطيات:** $F_\theta(x)$ تتغيّر بارامتر θ، احسب $\frac{d}{d\theta}\int h \, dF_\theta$.
- **المطلوب:** اشتقّ عبر التوزيع.
- **الحل:**

١. $\frac{d}{d\theta}\int h \, dF_\theta = \int h \, \frac{dF_\theta}{d\theta}$ (تبادل اشتقاق/تكامل مبرّر بـ DCT). ■

- **النتيجة:** مشتقّة التوقّع.
- **الربط بالذكاء الاصطناعي:** «تدرّج التوقّع حسب المعاملات» — أساس gradient policy و score function estimator.

مثال (12-7.10).

- **المعطيات:** توزيعان F, G، وزن $\lambda \in [0,1]$، عرّف $H = \lambda F + (1-\lambda)G$.
- **المطلوب:** $\int h \, dH$.
- **الحل:**

١. خطيّة Stieltjes: $\lambda \int h \, dF + (1-\lambda)\int h \, dG$. ■

- **النتيجة:** خليط (mixture).
- **الربط بالذكاء الاصطناعي:** «نموذج خليط غاوسي» (GMM) — توقّعه مجموع موزون لتوقّعات المكوّنات.

مثال (10.7-13).

- **المعطيات:** F القفزات عند x_i بـ p_i؛ احسب $\int (x-\mu)^2 dF$ (التباين).
- **المطلوب:** التباين.
- **الحل:**

١. $\sum_i (x_i-\mu)^2 p_i$ (الصيغة المنفصلة الكلاسيكية). ■

- **النتيجة:** التباين المنفصل.
- **الربط بالذكاء الاصطناعي:** «التباين = تكامل $(x-\mu)^2$» — كل مقاييس التشتّت (variance) تصيغها Stieltjes.

مثال (10.7-14).

- **المعطيات:** $F(x)=x^2$ على $[0,1]$ (توزيع بكثافة $2x$).
- **المطلوب:** $\mathbb{E}[X]=\int x\,dF$.
- **الحل:**

١. $F'(x)=2x \Rightarrow \int_0^1 x\cdot 2x\,dx = 2/3$. ■

- **النتيجة:** $2/3$.
- **الربط بالذكاء الاصطناعي:** «توزيع منحاز نحو 1» (كثافة متزايدة) — نموذج لـ bias preference في البيانات.

مثال (10.7-15).

- **المعطيات:** KL عبر Stieltjes: $D_{KL}(P\|Q)=\int \ln \frac{dP}{dQ}\,dP$.
- **المطلوب:** عبّر KL المنفصل والستيلتjes.
- **الحل:**

١. المنفصل: $\sum_i p_i \ln(p_i/q_i)$.

٢. العامّ: $\int \ln \frac{d\mu_P}{d\mu_Q}\,d\mu_P$ (مشتقّ رادون–نيكوديم). ■

- **النتيجة:** KL الموحّد.
- **الربط بالذكاء الاصطناعي:** «كل خسارة تشابه توزيعي (KL, JS, cross-entropy) هي تكامل Stieltjes» — الجسر إلى الفصل 26 (نظرية المعلومات) والـ ELBO في VAE.

خيط الفصل

١. **فضاء القياس (1.10)** يمنحنا «حجم الحدث» $\mu(A)$ — أساس كل احتمال.

٢. **قياس ليبيسغ (2.10)** يحلّ محلّ طول ريمان ويتعامل مع القفزات والمجموعات الشاذة.

٣. **الدوال القياسية (3.10)** تضمن أنّ كل مخرجات الشبكة «مرئية» للتكامل.

٤. **تكامل ليبيسغ (4.10)** يعرّف $\int f\,d\mu$ كحدّ أعلى لدوالّ بسيطة — ويشمل ديريكليه.

٥. **مبرهنات التقارب (5.10)** هي «رخصة تبادل الحدّ والتكامل». (MCT/Fatou/DCT)

٦. **ليبيسغ–ستيلتjes (6.10)** يربط F (CDF) بالتوقّع $\int h\,dF$ = أساس الإحصاء كله.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
$(\Omega, \mathcal{F}, \mathbb{P})$	كل نظرية الاحتمال (الفصل 13+)
$\int X\,d\mathbb{P} = \mathbb{E}[X]$	التوقّع والمخاطرة المتوقّعة
MCT / DCT	تبادل الحدّ والتكامل في التقارب
$\int h\,dF$	توقّع، ELBO، KL $\to$ CDF
التوزيع التجريبي	الجسر risk expected$\to$train (الفصل 30)
Radon–Nikodym	تغيير القياس في sampling importance / RL

١. أثبت أنّ $\mathcal{F} = 2^\Omega$ σ-جبرا لأيّ مجموعة منتهية Ω.

٢. لـ $A_n \uparrow A$ مع $\mu(A_1) < \infty$، أثبت $\mu(A) = \lim \mu(A_n)$ باستخدام القابلية العدّية.

٣. احسب $m(\{1/n : n \in \mathbb{N}\})$ على $\mathbb{R}$ بـ قياس ليبيسغ.

٤. بيّن أنّ مجموعة كانتور قياسها 0 مع أنّها غير عدّية.

٥. هل اتحاد σ-جبرتين دائماً σ-جبرا؟ اذكر مثالاً مضادّاً.

٦. أثبت أنّ f قياسية $\iff \{x : f(x) > a\} \in \mathcal{F}$ لكل a.

٧. لـ f, g قياسيتان، أثبت قياس $\max(f,g)$ و $\min(f,g)$.

٨. قرّب $f(x) = x^2$ على $[0,1]$ بدوالّ بسيطة $\phi_n \uparrow f$ واستنتج $\int_0^1 x^2 dx$.

٩. احسب $\int_{[0,1]} \mathbf{1}_{\mathbb{Q}}\,dx$ (ليبيسغ) وفسّر فرقها عن ريمان.

١٠. استخدم MCT لإثبات $\sum_{k=1}^{\infty} a_k = \int (\sum a_k \mathbf{1}_{\{k\}}) d\mu$ لـ $a_k \geq 0$.

١١. لـ $f_n = n\mathbf{1}_{(0,1/n)}$، بيّن لماذا لا ينطبق DCT وما $\lim \int f_n$.

١٢. طبّق Fatou على $f_n = \mathbf{1}_{(n,n+2)}$ على $\mathbb{R}$ وحدّد $\liminf \int f_n$.

١٣. أثبت أنّ $\int f_n \to \int f \implies \int |f_n - f| \to 0$.

١٤. لـ $F(x) = \mathbf{1}_{[a,\infty)}(x)$، احسب $\int h\,dF$ (دلتا عند a).

١٥. distribution منفصل $\{x_1, \dots, x_k\}$ باحتمالات p_i، اشتقّ $\mathrm{Var}(X) = \int (x-\mu)^2 dF$ كمجموع.

١٦. لـ $F(x) = 1 - e^{-x}$ $(x \geq 0)$، احسب $\mathbb{E}[X]$ و $\mathbb{E}[X^2]$ بالتكامل Stieltjes.

١٧. برهن خطيّة تكامل Stieltjes: $\int (ah + bg) dF = a\int h\,dF + b\int g\,dF$.

١٨. التوزيع التجريبي F_n بنقاط $\{x_i\}$ أوزان $1/n$؛ أثبت $\int h\,dF_n = \frac{1}{n}\sum h(x_i)$.

١٩. عبّر KL المنفصل $D_{KL}(P\|Q)$ كتكامل Stieltjes، واربطه بالتوقّع $\mathbb{E}_P[\ln(p/q)]$.

٢٠. تحدٍّ تركيبي: «لماذا risk expected = متوسّط الخسارة؟» — ابنِ F_n التجريبي من عيّنات، واستنتج $\int L\,dF_n = \frac{1}{n}\sum L(x_i)$، ثم اشرح متى يتقارب مع $\int L\,d\mathbb{P}$ (استخدم DCT أو تقارب ضعيف).

- **القياس (1.10):** $(\Omega, \mathcal{F}, \mu)$ بقابلية جمع عدّية، $\mu(\emptyset) = 0$ والاستمرارية من الأسفل/الأعلى.
- **ليبيسغ (2.10):** $m([a,b]) = b - a$، ثبات الترجمة والتجانس، والمجموعات العدّية (وحتى كانتور) قياسها 0.
- **القياسيّة (3.10):** f قياسية $\iff$ صورة كل بوريل عكسياً قياسية؛ كل f تُقرَّب بسيطة $\phi_n \uparrow f$.
- **التكامل (4.10):** $\int f\,d\mu = \sup$ على البسيطات؛ خطّي، يدمج ديريكليه بقيمة 0.
- **التقارب (5.10):** MCT (رتيب غير سالب)، Fatou ($\leq$)، DCT (محصور بـ g منتهية).
- **Stieltjes (6.10):** $\int h\,dF = \sum h(x_i)\Delta F_i$ (منفصل) أو $\int hF'dx$ (سلس)؛ الجسر إلى $\mathbb{E}[X]$ و KL.

الرمز	المعنى	أين عُرّف
$(\Omega, \mathcal{F}, \mu)$	فضاء القياس	(1.10)
$m(E)$	قياس ليبيسغ	(2.10)
$\mathbf{1}_A$	دالة المؤشّر	(3.10)
$\int f\,d\mu$	تكامل ليبيسغ	(4.10)
$f_n \uparrow f$	تقارب رتيب	نظرية 1.6.10
$\int h\,dF$	ليبيسغ–ستيلتjes	(6.10)
μ_F	القياس المرافق لـ F	(7.10)

١. W. Rudin, (1987). *Real and Complex Analysis*, 3rd ed., McGraw-Hill — المرجع الكنسي لنظرية القياس وتكامل ليبيسغ.

٢. G. Folland, (1999). *Real Analysis: Modern Techniques and Their Applications*, 2nd ed., Wiley — σ-جبرات، قياس ليبيسغ، ومبرهنات التقارب.

٣. P. Billingsley, (1995). *Probability and Measure*, 3rd ed., Wiley — الربط بين القياس والاحتمال والتكامل Stieltjes.

٤. S. Lahiri, & K. Athreya, (2006). *Measure Theory and Probability*, Springer — مقدمة لطيفة بأمثلة إحصائية.

٥. D. Cohn, (2013). *Measure Theory*, 2nd ed., Birkhäuser — تفاصيل σ-جبرا المولّدة والقياسات.

٦. T. Tao, (2011). *An Introduction to Measure Theory*, AMS — عرض حديث واضح للمبتدئين المتقدّمين.

٧. I., Goodfellow, Y. Bengio, & A. Courville (2016). *Deep Learning*, MIT Press (الفصل 3: التوزيعات والتوقّع كتكامل) — استخدامات ML المباشرة.

٨. K. Murphy, (2022). *Probabilistic Machine Learning*, MIT Press — التوقّعات والـ KL والتوزيع التجريبي في السياق التطبيقي.

متفاضلة تايلور وتحليل الأخطاء

الهدف من الفصل

خامس فصول الجزء الثاني (التفاضل والتكامل). أنهينا النهايات (7) والمشتقّة (8) والتفاضل المصفوفي (9) والتكامل/القياس (10). الآن نربط الاشتقاق بالتقريب: «كلّ ما لا نستطيع حسابه بدقّة نقرّبه بتايلور، وكلّ تقريب له خطأ نحلّله». الانحدار (gradient descent) هو تايلور من الدرجة الأولى؛ ونيوتن (Newton) هو تايلور من الدرجة الثانية؛ والتفاضل الآلي (autodffi) يحسب معاملات تايلور بدقّة.

أربعة أسباب تجعل هذا الفصل حجر الزاوية في الذكاء الاصطناعي:

١. **النماذج محليّاً متعدّدة حدود:** حول أيّ نقطة، $f(x+h) \approx f + \nabla^\top h + \frac{1}{2} h^\top \nabla^2 f\, h$. هذا يبرّر لماذا نعتمد التدرّج (الدرجة 1) ونيوتن (الدرجة 2).

٢. **التفاضل الآلي = معاملات تايلور:** backprop يحسب اليعقوبية والهِسّية — أيّ معاملات التوسّع — بدقّة رياضية لا تقريب فرقُ منتهٍ.

٣. **تحليل الأخطاء:** قطع السلسلة يُنتج «خطأ قطع» (truncation)؛ وانتشار الخطأ عبر طبقات الشبكة يُنتج «تكيّفاً سيّئاً» (ill-conditioning) — امتداد مباشر للفصل 6 (الاستقرار العددي).

٤. **التعلّم الحديث:** نيوتن، Natural Gauss-Newton، Gradient انتشار لانغفين (Langevin)، ومبرهنة Tweedie في dffiusion كلها صيغت بتايلور.

خريطة الفصل

القسم	الموضوع	الأداة المركزية
2.11	متسلسلة ومتعدّدات تايلور	$P_n(x)$
3.11	صيغ البقايا (Peano/تكاملي/Lagrange)	$R_n(x)$
4.11	تايلور متعدّد المتغيّرات	∇, ∇^2
5.11	خطأ القطع والتقارب	$O(h^{p+1})$
6.11	انتشار الخطأ والتكيّف	$\kappa(x)$
7.11	التطبيقات في الذكاء الاصطناعي	نيوتن/autodffi/Gauss-Newton

التعريف

dir="ltr"> <div

Definition 1.2.11 (Taylor polynomial). Let $f \in C^n$ near a. The **Taylor polynomial of** f **about** a is

$$P_n(x) = \sum_{k=0}^{n} \frac{f^{(k)}(a)}{k!}(x-a)^k. \tag{1.11}$$

dir="ltr"> <div
$a = 0$ About .f of **series Taylor** the is limit the interval, an on $n \to \infty$ as $P_n(x) \to f(x)$ If .**series Maclaurin** the called is it

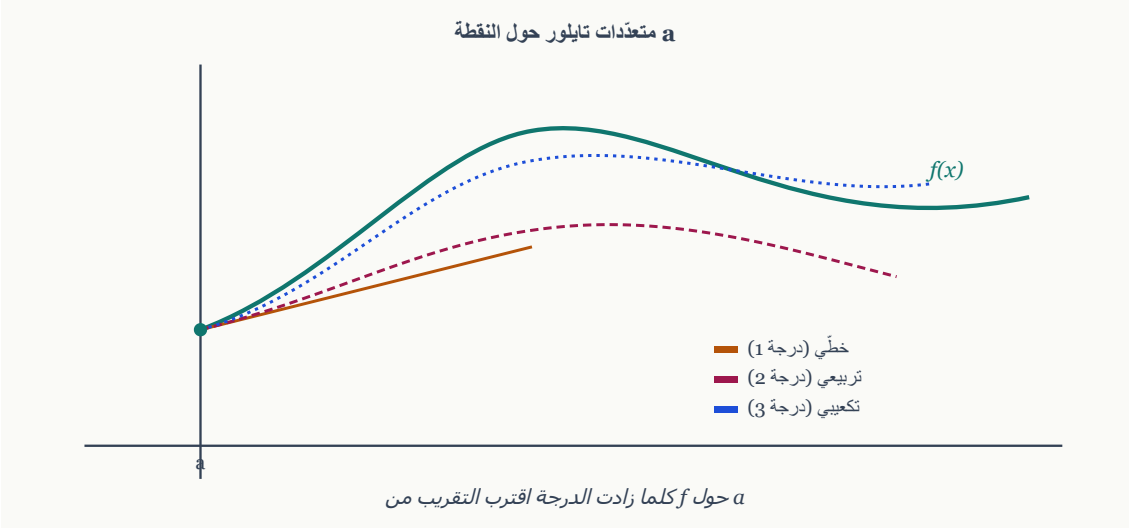
النظرية 1.2.11 (صيغ كلاسيكية): $(1+x)^\alpha = ,\sin x = \sum(-1)^k x^{2k+1}/(2k+1)!\ ,e^x = \sum x^k/k!$ $.1/(1-x) = \sum x^k\ ,\sum \binom{\alpha}{k} x^k$

جدول الرموز

الرمز	الاسم	المعنى
P_n	متعدّدة تايلور	تقريب حدّي الدرجة n
$f^{(k)}$	المشتقّة k	معامل الحدّ k
a	مركز التوسّع	نقطة التقارب المحلّي

رسم توضيحي

<figure> الشكل<figcaption> 1.11: حول a، الخطّ المستقيم (درجة 1) ثمّ التربيعي (2) ثمّ التكعيبي (3) يلتفّون



a حول f كلما زادت الدرجة اقترب التقريب من

شكل ١.١١: *
متعدّدات تايلور من الدرجات 1 و2 و3

حول f. كلّما زادت الدرجة اقترب التقريب — محليّاً على الأقلّ.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«تايلور يتقارب دائماً»	قد تفشل السلسلة خارج نصف القطر	افحص نصف القطر
خلط $(x-a)$ مع x	المركز a أساسيّ	استخدم $(x-a)$ دائماً
نسيان العامل $k!$	معاملات خاطئة	اقسم على العاملي
اعتبار P_n تقريباً عالمياً	هو محليّ حول a	«قرب a» شرط صريح

أمثلة محلولة على متسلسلة ومتعدّدات تايلور (15 مثالاً)

مثال (11.2-1).

- **المعطيات:** $f(x) = e^x$ حول $a = 0$.
- **المطلوب:** اكتب $P_3(x)$.
- **الحل:**

١. $f^{(k)}(0) = 1$ لكل k.

٢. $P_3 = 1 + x + \frac{x^2}{2} + \frac{x^3}{6}$. ■

- **النتيجة:** $1 + x + x^2/2 + x^3/6$.
- **الربط بالذكاء الاصطناعي:** «تقريب exp بخطوات» — أساس تثبيت softmax العددي (log-sum-exp من الفصل 6).

مثال (11.2-2).

- **المعطيات:** $f(x) = \sin x$ حول 0.
- **المطلوب:** $P_5(x)$.
- **الحل:**

١. المشتقّات بالتناوب $1, 0, -1, 0, 1, 0$ عند 0.

٢. $P_5 = x - \frac{x^3}{6} + \frac{x^5}{120}$. ■

- **النتيجة:** الحدود الفردية فقط.
- **الربط بالذكاء الاصطناعي:** «تقريب زاوية صغيرة» $\sin x \approx x$ يُستخدم في دوران الكاميرا والفيزياء المحاكاة.

مثال (11.2-3).

- **المعطيات:** $f(x) = \cos x$ حول 0.
- **المطلوب:** $P_4(x)$.
- **الحل:**

١. المشتقّات $0, -1, 0, 1, 0$.

٢. $P_4 = 1 - \frac{x^2}{2} + \frac{x^4}{24}$. ■

- **النتيجة:** الحدود الزوجية.
- **الربط بالذكاء الاصطناعي:** «تقريب التغيير الطفيف» $\cos x \approx 1 - x^2/2$ في تنعيم الإشارات.

مثال (11.2-4).

- **المعطيات:** $f(x) = \ln(1+x)$ حول 0.
- **المطلوب:** $P_3(x)$ ونصف القطر.
- **الحل:**

١. $f'(0) = 1,\ f''(0) = -1,\ f'''(0) = 2$.

٢. $P_3 = x - \frac{x^2}{2} + \frac{x^3}{3}$؛ نصف القطر $= 1$ (متفرّع عند $x = -1$). ■

- **النتيجة:** سلسلة متناوبة.
- **الربط بالذكاء الاصطناعي:** «تقريب log(1+x) صغير» يُستخدم في خسارة السجلّ (log-loss) حول الصفر.

مثال (11.2-5).

- **المعطيات:** $f(x) = (1+x)^{\alpha}$ حول 0.
- **المطلوب:** أوّل ثلاثة حدود (ذات الحدّين العامّ).
- **الحل:**

١. $f'(0) = \alpha,\ f''(0) = \alpha(\alpha-1)$.

٢. $1 + \alpha x + \frac{\alpha(\alpha-1)}{2}x^2 + \cdots$. ■

- **النتيجة:** معاملات ذات الحدّين.
- **الربط بالذكاء الاصطناعي:** «تقريب القوى» لمشتقّات w.r.t. معاملات في بايز السلس (Laplace approximation).

مثال (11.2-6).

- **المعطيات:** $f(x) = \frac{1}{1-x}$ حول 0.
- **المطلوب:** السلسلة ونصف القطر.
- **الحل:**

١. مشتقّات: $f^{(k)}(0) = k!$.

٢. $\sum_{k=0}^{\infty} x^k$؛ نصف القطر 1. ■

- **النتيجة:** هندسية.
- **الربط بالذكاء الاصطناعي:** «جمع هندسي» = قيمة خصم المكافآت في التعزيزي $\sum \gamma^k$.

مثال (11.2-7).

- **المعطيات:** $f(x) = \arctan x$ حول 0.
- **المطلوب:** $P_3(x)$.
- **الحل:**

١. $f'(0) = 1,\ f'''(0) = -2$.

٢. $x - \frac{x^3}{3}$. ■

- **النتيجة:** متناوبة فردية.
- **الربط بالذكاء الاصطناعي:** «تقريب الزاوية» في تقدير الاتجاه من الميل.

مثال (11.2-8).

- **المعطيات:** $\sinh x, \cosh x$ حول 0.
- **المطلوب:** السلسلتان.
- **الحل:**

١. $\sinh x = x + \frac{x^3}{6} + \cdots$؛ $\cosh x = 1 + \frac{x^2}{2} + \cdots$. ■

- **النتيجة:** فردية/زوجية منفصلة.
- **الربط بالذكاء الاصطناعي:** «دوالّ القطع الزائدي» تظهر في sinh-acceleration والشبكات بـ swish.

مثال (11.2-9).

- **المعطيات:** e^{ix} حول 0.
- **المطلوب:** اشتقّ صيغة أويلر.
- **الحل:**

١. $P = \sum (ix)^k/k! = \big(\sum (-1)^k x^{2k}/(2k)!\big) + i\big(\sum (-1)^k x^{2k+1}/(2k+1)!\big)$.

٢. $= \cos x + i \sin x$. ■

- **النتيجة:** $e^{ix} = \cos x + i \sin x$.
- **الربط بالذكاء الاصطناعي:** «الترميز الموضعي» (positional encoding) في المحوّلات يستخدم $\sin$ / $\cos$ — جذورها من أويلر.

مثال (10-2.11).

- **المعطيات:** قرّب $\sqrt{1.1}$ بـ $(1+x)^{1/2}$ عند $x = 0.1$.
- **المطلوب:** تقدير بدرجة 2.
- **الحل:**

١. $1 + \frac{1}{2}(0.1) - \frac{1}{8}(0.1)^2 = 1 + 0.05 - 0.00125 = 1.04875$. ■

- **النتيجة:** $1.0488 \approx$ (الحقيقي 1.0488).
- **الربط بالذكاء الاصطناعي:** «تقريب الجذر» لتطبيع الأوزان (weight normalization).

مثال (11-2.11).

- **المعطيات:** قرّب $e^{0.1}$ بدرجة 3.
- **المطلوب:** القيمة.
- **الحل:**

١. $1 + 0.1 + 0.005 + 0.0001667 = 1.1051667$. ■

- **النتيجة:** ≈ 1.10517.
- **الربط بالذكاء الاصطناعي:** «تقريب exp صغير» في حساب الاحتمالات اللحظية.

مثال (12-2.11).

- **المعطيات:** $f(x) = \ln \frac{1+x}{1-x}$ حول 0.
- **المطلوب:** P_3.
- **الحل:**

١. $\ln(1+x) - \ln(1-x) = (x - x^2/2 + x^3/3) - (-x - x^2/2 - x^3/3) = 2x + 2x^3/3$. ■

- **النتيجة:** $2x + \frac{2}{3}x^3$.
- **الربط بالذكاء الاصطناعي:** «دالة atanh» تُستخدم في ربط القيم المستمرّة (Gumbel/Concrete relaxation).

مثال (13-2.11).

- **المعطيات:** $f(x) = x^3$ حول $a = 2$.

- **المطلوب:** $P_3(x)$ (يجب أن تساوي f تماماً).
- **الحل:**

١. $f(2)=8,\ f'(2)=12,\ f''(2)=12,\ f'''(2)=6$.

٢. $8+12(x-2)+6(x-2)^2+(x-2)^3=x^3$ (تحقّق بالفكّ). ■

- **النتيجة:** متطابقة — متعدّدة حدود = تايلور اللانهائي.
- **الربط بالذكاء الاصطناعي:** «أيّ متعدّدة حدود هي تايلورها» — أساس تمثيل كثيرات الحدود في الطبقات.

مثال (11.2-14).

- **المعطيات:** e^x، نصف القطر ؟ $=$
- **المطلوب:** أثبت التقارب لكلّ x.
- **الحل:**

١. نصف القطر $=\lim|a_k/a_{k+1}|=\infty$. ■

- **النتيجة:** سلسلة كاملة (entire).
- **الربط بالذكاء الاصطناعي:** «لا حدود تقارب» $\Longrightarrow$ تقريب exp موثوق لأيّ مقياس — سبب استقراره العددي.

مثال (11.2-15).

- **المعطيات:** عيّنات (x_i,y_i)، استيفاء متعدّد حدود درجة n.
- **المطلوب:** اربطه بتايلور.
- **الحل:**

١. الاستيفاء يمرّ بالنقاط؛ تايلور يمرّ بالمشتقّات عند a — كلاهما «تحديد متعدّدة بـ $n+1$ معامل». ■

- **النتيجة:** وجهان لنفس البناء.
- **الربط بالذكاء الاصطناعي:** «استيفاء البيانات» = تركيب متعدّدة تقرّب العيّنات — نواة كل انحدار كثير الحدود.

التعريف

dir="ltr"> <div

forms: Three .$R_n(x) = f(x) - P_n(x)$ **(Remainder). 1.3.11 Definition**

- **Lagrange:** $R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}(x-a)^{n+1}$ some for $\xi \in (a,x)$.
- **Integral:** $R_n(x) = \int_a^x \frac{f^{(n+1)}(t)}{n!}(x-t)^n\,dt$.
- **Peano:** $R_n(x) = o\big((x-a)^n\big)$.

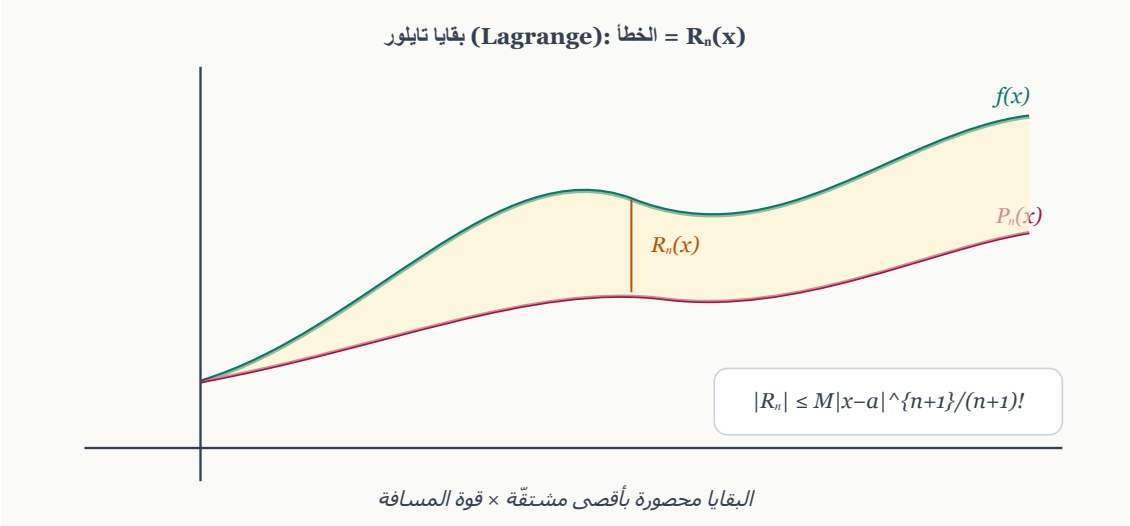
$$|R_n(x)| \le \frac{M}{(n+1)!}\,|x-a|^{n+1}, \quad M = \max|f^{(n+1)}|. \tag{2.11}$$

جدول الرموز

الرمز	الاسم	المعنى
R_n	البقايا	الخطأ بعد قطع الدرجة n
ξ	نقطة وسيطة	موجودة نظرياً في لاغرانج
M	أقصى مشتقّة	يضبط الحدّ الأعلى للخطأ

رسم توضيحي

<figure> الشكل<figcaption> 2.11: الخطأ $R_n(x)$ هو المساحة بين f و P_n. لاغرانج يضمن وجود ξ يجعل



شكل ٢.٠١١: *
البقايا كالمنطقة بين f و P_n

$|R_n| \le M|x-a|^{n+1}/(n+1)!$ — أيّ أنّ البقايا محصورة بأقصى انحناء.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اعتبار ξ معروفة	هي نظرية الوجود فقط	نستخدمها للحدّ الأعلى لا القيمة
نسيان M يعتمد على n	أعلى مشتقّة بتغيّر	خذ أقصى $\lvert f^{(n+1)}\rvert$ على الفترة
خلط Peano مع قيمة عددية	$o(\cdot)$ غير كمّي	استخدم لاغرانج للتقدير العملي
تجاهل أنّ $(x-a)^{n+1}$ قد يكبر	بعيداً عن a يكبر الخطأ	التقارب محلّي

أمثلة محلولة على صيغ البقايا (15 مثالاً)

مثال (11.3-1).

- **المعطيات:** e^x حول 0، تقدير لـ $R_2(x)$.
- **المطلوب:** حدّ أعلى للخطأ عند $x=1$.
- **الحل:**

١. $M = \max e^{\xi} = e^1 = e$ على $[0,1]$.

٢. $|R_2| \le e \cdot 1^3/6 \approx 0.453$. ■

- **النتيجة:** ≤ 0.453 (الحقيقي $e - 2.5 \approx 0.218$).
- **الربط بالذكاء الاصطناعي:** «حدّ أعلى لخطأ التقريب» — يضمن أمان تقدير exp المقطوع.

مثال (11.3-2).

- **المعطيات:** $\sin x$، P_3 عند $x=0.5$.
- **المطلوب:** حدّ لاغرانج.
- **الحل:**

١. $f^{(4)}(\xi) = -\sin\xi$، $|M| \le 1$.

٢. $|R_3| \le |0.5|^4/24 \approx 0.0026$. ■

- **النتيجة:** ≤ 0.0026.
- **الربط بالذكاء الاصطناعي:** «خطأ تقريب زاوية صغيرة» محدود — يبرّر إهمال الحدود العليا في الاستشعار.

مثال (11.3-3).

- **المعطيات:** $e^{0.1}$ بدرجة 1.
- **المطلوب:** خطأ لاغرانج.

- **الحل:**

١. $R_1 \le e^{0.1}(0.1)^2/2 \approx 1.105 \cdot 0.005 = 0.0055$. ■

- **النتيجة:** ≤ 0.0055.

- **الربط بالذكاء الاصطناعي:** «دقّة التقريب الخطّي» تحدّد خطوة التعلّم الآمنة محليّاً.

مثال (11.3-4).

- **المعطيات:** تقريب e^1 بخطأ $< 10^{-6}$.

- **المطلوب:** أصغر n؟

- **الحل:**

١. $|R_n| \le e/(n+1)! < 10^{-6}$.

٢. لـ $n = 9$: $e/10! \approx 2.718/3.6 \times 10^6 \approx 7.5 \times 10^{-7} < 10^{-6}$. ■

- **النتيجة:** $n = 9$.

- **الربط بالذكاء الاصطناعي:** «عدد الحدود لدقّة مطلوبة» — يشبه اختيار عرض النطاق الترددي لاكتساب النموذج.

مثال (11.3-5).

- **المعطيات:** e^x، الصيغة التكاملية لـ R_n.

- **المطلوب:** أثبت أنّها تؤول لـ e^x.

- **الحل:**

١. $R_n = \int_0^x e^t (x-t)^n/n!\, dt \le e^x x^{n+1}/(n+1)! \to 0$. ■

- **النتيجة:** التقارب مضمون.

- **الربط بالذكاء الاصطناعي:** «صيغة التكامل» تظهر في اشتقاق ELBO التكراري (المتبقّى يصغر).

مثال (11.3-6).

- **المعطيات:** f قابلة للاشتقاق n مرّة عند a.

- **المطلوب:** صيغة بيانو $R_n = o((x-a)^n)$.

- **الحل:**

١. من لاغرانج $R_n/|x-a|^n \to 0$؛ بيانو يصف السرعة فقط. ■

- **النتيجة:** o لا قيمة.

- **الربط بالذكاء الاصطناعي:** «تحليل الأخطاء اللانهائي الصغر» في براهين التقارب الطوبولوجي.

مثال (11.3-7).

- **المعطيات:** $\cos x$، P_2 عند $x = 0.3$.
- **المطلوب:** حدّ لاغرانج.
- **الحل:**

١. $f^{(3)}(\xi) = -\sin\xi$، $|M| \le 0.3$ (على $[0, 0.3]$) أو بأمان 1.

٢. $|R_2| \le 1 \cdot (0.3)^3/6 \approx 0.0045$. ■

- **النتيجة:** ≤ 0.0045.
- **الربط بالذكاء الاصطناعي:** «تقدير تحفّظي» — نأخذ $M = 1$ دائماً لضمان الحدّ الأعلى.

مثال (11.3-8).

- **المعطيات:** سلسلة متناوبة ترضي شرط ليبنتس.
- **المطلوب:** اربط بقايا لاغرانج.
- **الحل:**

١. الخطأ $\le$ أول حدّ مهمَل = صورة خاصّة من لاغرانج لـ $f^{(n+1)}$ متناوبة. ■

- **النتيجة:** متراجحة ليبنتس = لاغرانج.
- **الربط بالذكاء الاصطناعي:** «حدّ خطأ متناوب» يُستخدم في تقريب سريع بلا تقييم كلّ الحدود.

مثال (11.3-9).

- **المعطيات:** $\arctan x$ عند $x = 1$ بـ P_3.
- **المطلوب:** حدّ بقايا.
- **الحل:**

١. $f^{(4)}(x) = -6x(1+x^2)^{-3}$؛ $|M| \le 6$ على $[0, 1]$.

٢. $|R_3| \le 6/24 = 0.25$. ■

- **النتيجة:** ≤ 0.25 (فجوة بسبب بطء تقارب $\arctan$ عند 1).
- **الربط بالذكاء الاصطناعي:** «بطء التقارب عند الحافة» — يذكّر بنصف القطر المحدود.

مثال (10-3.11).

- **المعطيات:** $\ln(1+x)$، الصيغة التكاملية.
- **المطلوب:** عبّر R_n تكاملياً.
- **الحل:**

١. $R_n = \int_0^x \frac{(-1)^n n!}{(1+t)^{n+1}} \frac{(x-t)^n}{n!} dt = \int_0^x \frac{(-1)^n (x-t)^n}{(1+t)^{n+1}} dt$. ■

- **النتيجة:** صيغة تكاملية مغلقة.
- **الربط بالذكاء الاصطناعي:** «صيغة التكامل» تظهر في اشتقاق تقديرات بايز التحليلية.

مثال (11-3.11).

- **المعطيات:** قطع عند n $\Longrightarrow$ خطأ $O(|x-a|^{n+1})$.
- **المطلوب:** اربط بالترتيب.
- **الحل:**

١. من (2.11): $|R_n| \le M|x-a|^{n+1}/(n+1)! \Longrightarrow$ رتبة $n+1$. ■

- **النتيجة:** رتبة الخطأ $= n+1$.
- **الربط بالذكاء الاصطناعي:** «رتبة الخطأ» تقابل دقّة المقدّر حسب عدد الحدود.

مثال (12-3.11).

- **المعطيات:** $(1+x)^{\alpha}$ عند $x = 0.2$.
- **المطلوب:** حدّ البقايا لـ P_2.
- **الحل:**

١. $f^{(3)}(\xi) = \alpha(\alpha-1)(\alpha-2)(1+\xi)^{\alpha-3}$؛ لـ $\alpha = 1/2$، $|M| \le \frac{3}{4}(1)^{-2.5} = 0.375$.

٢. $|R_2| \le 0.375(0.2)^3/6 \approx 0.0005$. ■

- **النتيجة:** $\le 5 \times 10^{-4}$.
- **الربط بالذكاء الاصطناعي:** «خطأ تقريب الجذر» صغير قرب الصفر — موثوق لتطبيع الأوزان.

مثال (13-3.11).

- **المعطيات:** برهان (مخطّط) أنّ e غير نسبي عبر البقايا.
- **المطلوب:** اشرح الفكرة.
- **الحل:**

١. لو $e=p/q$، $q!\,e=q!\sum_{k=0}^{\infty}1/k!$؛ الجزء الذيل $q!\int_0^1 e^t(1-t)^q/q!dt$ يقع بين 0 و1 غير صحيح $\Longrightarrow$ تناقض. ■

- **نتيجة:** فكرة الاعتماد على ضبط البقايا.
- **الربط بالذكاء الاصطناعي:** «ضبط الخطأ لإثبات استحالة» — نمط يظهر في حدود قدرة التعلّم (PAC).

مثال (14-3.11).

- **المعطيات:** $f'(a)=0$ (نقطة حرجة).
- **المطلوب:** ماذا عن R_1؟
- **الحل:**

١. $P_1=f(a)$، $R_1=f(a+h)-f(a)=\frac{1}{2}f''(\xi)h^2$. ■

- **النتيجة:** الخطأ من الرتبة الثانية فوراً.
- **الربط بالذكاء الاصطناعي:** «عند النقطة الحرجة التقريب الخطّي ثابت» — أساس تحليل الحوض حول المُثلّث.

مثال (15-3.11).

- **المعطيات:** وجود ξ في لاغرانج لا قيمته.
- **المطلوب:** بيّن أنّنا نقدّر لا نحسب.
- **الحل:**

١. ξ وسيطة مضمونة لكنها تختلف بـ x ولا تُعبَّر صراحةً عادةً. ■

- **النتيجة:** نستخدمها للحدّ الأعلى.
- **الربط بالذكاء الاصطناعي:** «ضمان وجود بلا حساب» — مثل وجود الحلّ الأمثل في التعلّم المحدّب.

التعريف

dir="ltr"> <div
with ,**x** near C^2 class of $f : \mathbb{R}^d \to \mathbb{R}$ For **Taylor). (Multivariate 1.4.11 Definition**
:**h** increment

$$f(\mathbf{x}+\mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \tfrac{1}{2}\mathbf{h}^\top \nabla^2 f(\mathbf{x})\,\mathbf{h} + R_2. \tag{3.11}$$

dir="ltr"> <div
. $R_2 = o(\|\mathbf{h}\|^2)$ satisfies remainder The Hessian. the $\nabla^2 f$ and gradient the is ∇f Here

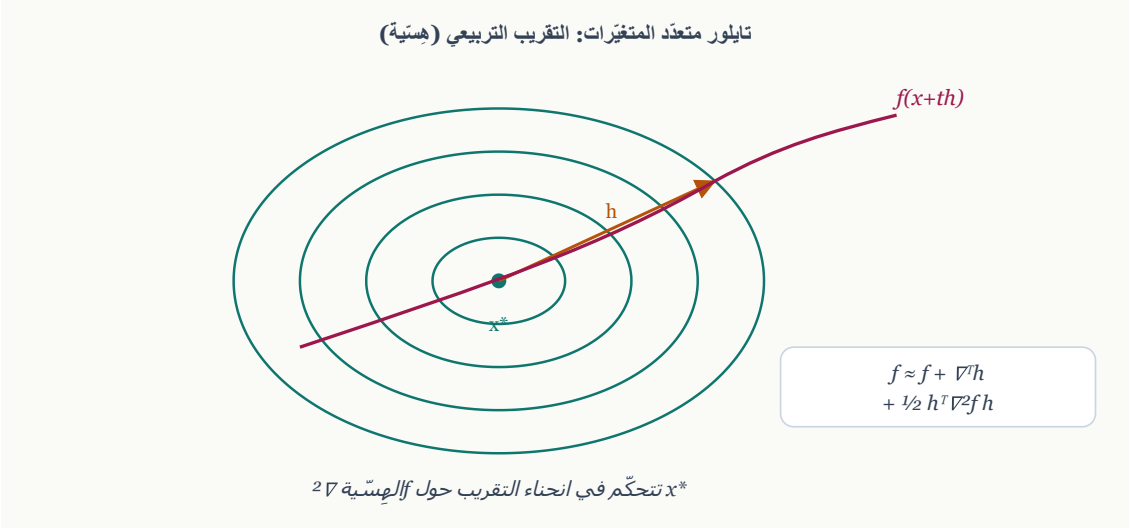
النظرية 1.4.11 (اتجاه الانحناء): الانحناء على طول **v** هو $\mathbf{v}^\top \nabla^2 f\,\mathbf{v}$؛ قيمه الذاتية تحدّد التقوّس (موجب=وعرة، سالب=سرج).

جدول الرموز

الرمز	الاسم	المعنى
∇f	التدرّج	متجه الدرجة الأولى
$\nabla^2 f$	الهِسّية	مصفوفة الدرجة الثانية
$\mathbf{h}$	الخَطوة	متجه الإزاحة

رسم توضيحي

<figure> الشكل<figcaption> 3.11: حول x^*، الدالة تُقرَّب بوعاء بيضاوي (متساويات الهِسّية). الخطّ الأحمر h



شكل ٣.١١: *
التقريب التربيعي وحوض الهِسّية

يقطع قطاعاً تربيعياً، انحناؤه = $h^\top \nabla^2 f\, h$.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
نسيان $\frac{1}{2}$ في الحدّ التربيعي	معامل هِسّية	اكتب $\frac{1}{2}h^\top Hh$
اعتبار الهِسّية دائماً موجبة	قد تكون سرجية	فحص القيم الذاتية
خلط ∇^2 مع $\nabla\nabla^\top$	الأولى هِسّية	$H_{ij} = \partial^2 f/\partial x_i \partial x_j$
إهمال بقايا الترتيب الثاني	الخطأ $o(\|h\|^2)$	لا تهمل إلا محلياً صغيراً

أمثلة محلولة على تايلور متعدّد المتغيّرات (15 مثالاً)

مثال (11.4-1).

- **المعطيات:** $f(x) = \frac{1}{2}x^\top Ax + b^\top x$ (تربيعي).
- **المطلوب:** أثبت تطابق تايلور من الدرجة 2 مع f.
- **الحل:**

١. $\nabla f = Ax + b$، $\nabla^2 f = A$.

٢. $f(x+h) = f + \nabla^\top h + \frac{1}{2}h^\top Ah = f$ تماماً (لا بقايا). ■

- **النتيجة:** متطابق.
- **الربط بالذكاء الاصطناعي:** «الخسائر التربيعية = تايلور تامّ» — أساس least squares و Newton.

مثال (11.4-2).

- **المعطيات:** $f(x,y) = x^2 + y^2$ عند $(0,0)$.
- **المطلوب:** الهِسّية.
- **الحل:**

١. $\nabla = (2x, 2y)$؛ $H = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$. ■

- **النتيجة:** $2I$ موجبة — حوض كروي.
- **الربط بالذكاء الاصطناعي:** «هِسّية موجبة ثابتة» = تقوّس متّسق — حالة مثالية لنيوتن.

مثال (11.4-3).

- **المعطيات:** عند نقطة حرجة $\nabla f = 0$، اقترب تربيعياً.
- **المطلوب:** اشتقّ اتجاه نيوتن.

- **الحل:**

١. $f(x+h) \approx f + \frac{1}{2}h^\top Hh$؛ نُصغّر: $\nabla(\frac{1}{2}h^\top Hh) = Hh = 0$.

٢. حلّ $Hh = -\nabla \implies h = -H^{-1}\nabla$. ■

- **النتيجة:** خطوة نيوتن.

- **الربط بالذكاء الاصطناعي:** «اتجاه نيوتن» = حلّ نظام خطّي بالهِسّية — أساس التحسين من الدرجة الثانية.

مثال (4-4.11).

- **المعطيات:** $f(x,y) = x^2 - y^2$ عند $(0,0)$.

- **المطلوب:** ماذا تدلّ الهِسّية؟

- **الحل:**

١. $H = \mathrm{diag}(2,-2)$ — قيم ذاتية متباينة الإشارة $\implies$ نقطة سرجية. ■

- **النتيجة:** سرج (saddle).

- **الربط بالذكاء الاصطناعي:** «نقاط السرج» تسيطر على فضاءات الشبكات العميقة (هضاب مسطّحة + سروج).

مثال (5-4.11).

- **المعطيات:** $f(x) = -\frac{1}{2}x^\top \Sigma^{-1} x$ (أسّ سلبي لتوزيع).

- **المطلوب:** التقريب التربيعي.

- **الحل:**

١. $\nabla = -\Sigma^{-1}x$، $\nabla^2 = -\Sigma^{-1}$؛ التقريب مطابق للأسّ. ■

- **النتيجة:** غاوسي = تربيعي تامّ.

- **الربط بالذكاء الاصطناعي:** «تقارب غاوسي بتايلور» = أساس approximation Laplace في بايز.

مثال (6-4.11).

- **المعطيات:** بقايا المربعات الصغرى $R(\beta) = \|y - X\beta\|^2$.

- **المطلوب:** الهِسّية.

- **الحل:**

١. $\nabla = -2X^\top(y - X\beta)$؛ $H = 2X^\top X$ (ثابتة موجبة شبه-معرّفة). ■

- **النتيجة:** هِسّية ثابتة.

- **الربط بالذكاء الاصطناعي:** «هِسّية constant» $\implies$ نيوتن يحلّ بخطوة واحدة — خاصّية least squares.

مثال (11.4-7).

- **المعطيات:** خسارة لوجستيك $\ell(\beta) = \sum \log(1 + e^{-y_i x_i^\top \beta})$.
- **المطلوب:** الهِسّية قرب المُثلّث.
- **الحل:**

١. $H = X^\top D X$، $D = \mathrm{diag}(p_i(1-p_i))$ موجبة المعرّفة. ■

- **النتيجة:** موجبة — محليّاً محدّب.
- **الربط بالذكاء الاصطناعي:** «هِسّية لوجستيك موجبة» تضمن تقارب نيوتن-لوجستيك.

مثال (11.4-8).

- **المعطيات:** انحناء على طول اتجاه الوحدة v.
- **المطلوب:** أثبت $= v^\top H v$.
- **الحل:**

١. $f(x+tv) = f + t\nabla^\top v + \frac{1}{2}t^2 v^\top H v + \cdots$؛ المشتقّة الثانية عند 0 هي $v^\top H v$. ■

- **النتيجة:** الانحناء الاتّجاهي.
- **الربط بالذكاء الاصطناعي:** «انحناء الاتجاه» يحدّد أين تتسطّح الخسارة — تحليل حادّة النموذج.

مثال (11.4-9).

- **المعطيات:** لابلاسيان $\Delta f = \sum \partial^2 f / \partial x_i^2$.
- **المطلوب:** اربطه بتايلور.
- **الحل:**

١. من تايلور: $f(x+he_i) + f(x-he_i) - 2f(x) = h^2 \partial^2 f/\partial x_i^2 + o(h^2)$؛ جمع الأبعاد $= h^2 \Delta f$. ■

- **النتيجة:** لابلاسيان = مجموع الانحناءات.
- **الربط بالذكاء الاصطناعي:** «اللابلاسيان المنفصل» = التفاف شبكي (CNN) — أساس الترشيح.

مثال (11.4-10).

- **المعطيات:** $f(x,y)=xy$ عند $(0,0)$.
- **المطلوب:** الحدّ التربيعي.
- **الحل:**

١. $\nabla=(y,x)=0$؛ $H=\begin{bmatrix}0&1\\1&0\end{bmatrix}$؛ الحدّ $=xy$ (مطابق). ■

- **النتيجة:** سرج بلا حدّ خطّي.
- **الربط بالذكاء الاصطناعي:** «حدود التفاعل xy» تظهر في ميزات المنتج والاهتمام.

مثال (11-4.11).

- **المعطيات:** عند نقطة حرجة، $f(x+h)=f+\frac{1}{2}h^{\top}Hh+o(\|h\|^2)$.
- **المطلوب:** صنّف حسب H.
- **الحل:**

١. موجبة $\Rightarrow$ أدنى محليّ؛ سالبة $\Rightarrow$ أعلى؛ متباينة $\Rightarrow$ سرج. ■

- **النتيجة:** تصنيف نيوتن-رافسون.
- **الربط بالذكاء الاصطناعي:** «تصنيف النقطة الحرجة» = فهم مشهد التحسين (loss landscape).

مثال (12-4.11).

- **المعطيات:** لوغاريتم softmax $g_i=\log\sum_j e^{z_j}$ عند z.
- **المطلوب:** التدرّج والهِسّية.
- **الحل:**

١. $\nabla g=p$؛ $H=\operatorname{diag}(p)-pp^{\top}$ (softmax) (موجبة شبه-معرّفة). ■

- **النتيجة:** هِسّية softmax معروفة.
- **الربط بالذكاء الاصطناعي:** «هِسّية softmax» تُستخدم في التحسين والتحليل التباينيّ للاحتمالات.

مثال (13-4.11).

- **المعطيات:** قيم ذاتية لـ H عند نقطة.

- **المطلوب:** ماذا تدلّ؟
- **الحل:**

١. هي انحناءات رئيسية (principal curvatures)؛ أصغرها يقارب أخطر اتجاه لتسطّح. ■

- **النتيجة:** «شكل الوعاء».
- **الربط بالذكاء الاصطناعي:** «القيم الذاتية للهِسّية» تقيس حادّة/تسطّح النموذج — مؤشّر التعميم.

مثال (11.4-14).

- **المعطيات:** خطوة نيوتن مقابل التدرّج.
- **المطلوب:** قارن.
- **الحل:**

١. تدرّج: $h = -\eta \nabla$ (لا يعرف الانحناء). نيوتن: $h = -H^{-1}\nabla$ (يضبط حسب الانحناء). ■

- **النتيجة:** نيوتن أسرع محليّاً.
- **الربط بالذكاء الاصطناعي:** «تكييف الخطوة بالهِسّية» = جوهر محسّنات/Adam الجيل الثاني.

مثال (11.4-15).

- **المعطيات:** $f(x_1, x_2) = x_1^2 + 2x_1x_2 + 3x_2^2$ عند $(0, 0)$.
- **المطلوب:** الحدّ التربيعي الكامل.
- **الحل:**

١. $H = \begin{bmatrix} 2 & 2 \\ 2 & 6 \end{bmatrix}$ موجبة المعرّفة؛ $f = \frac{1}{2}h^\top Hh$ بالضبط. ■

- **النتيجة:** تربيعي مطابق.
- **الربط بالذكاء الاصطناعي:** «صيغ تربيعية بحدود تفاعل» — نموذج كلّ شبكة خطّية/تربيعية.

التعريف

dir="ltr"> <div
-th$n$ the after series Taylor a Cutting **order). & error (Truncation 1.5.11 Definition**
satisfies error its fi p **order** is method A .R_n error truncation leaves term

$$|E| \leq C\,|x-a|^{n+1} \quad \text{generally more or} \quad E = O(h^{p+1}). \tag{4.11}$$

dir="ltr"> <div
the fi **convergent** and ,h $\to$ 0 as holds bound the fi **asymptotic** is error say We
value. true the to tends itsefl approximation

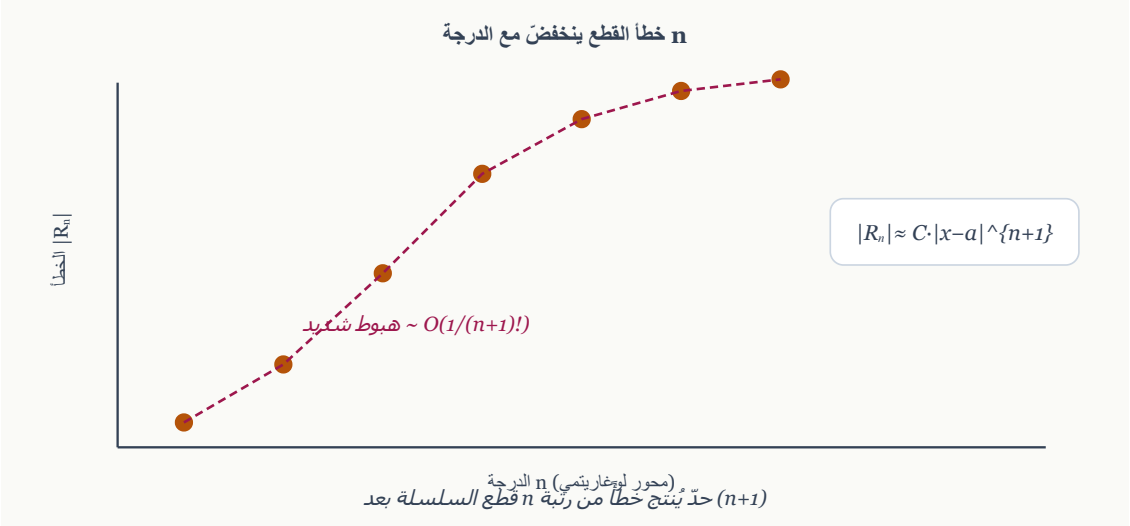
النظرية 1.5.11 (ترتيب الفروق): الفرق الأمامي $O(h)$، المركزي $O(h^2)$، وصيغ أكثر تماثلاً ترفع الرتبة.

جدول الرموز

الرمز	الاسم	المعنى
R_n	خطأ القطع	ما حُذف من السلسلة
p	الرتبة	قوة h في الخطأ
$O(\cdot)$	ترتيب كبير	سلوك حدّي

رسم توضيحي

<figure> الشكل<figcaption> 4.11: على محور لوغاريتمي، خطأ القطع $|R_n|$ يهبط بسرعة مع الدرجة n (تقريباً كـ



شكل ٤.٠١١: *
انخفاض خطأ القطع مع الدرجة

$1/(n+1)!$. قطع أبكر = رتبة أقلّ = خطأ أكبر.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
«رتبة أعلى دائماً أفضل» خلط $O(h^p)$ مع $O(h^{p+1})$	تكلفة حسابية تزداد تعريف الرتبة	توازن دقّة/تكلفة الخطأ $O(h^{p+1})$ للدرجة p
نسيان أنّ O وصفي لا قيمي	لا يعطي الثابت C	قيّم C عملياً
اعتبار التقارب اللانهائي قريباً	قد يبطئ جداً	فحص رتبة النقصان

أمثلة محلولة على خطأ القطع والتقارب (15 مثالاً)

مثال (11.5-1).

- **المعطيات:** الفرق الأمامي $f'(x) \approx \frac{f(x+h)-f(x)}{h}$.
- **المطلوب:** رتبة الخطأ.
- **الحل:**

١. $f(x+h) = f + hf' + \frac{h^2}{2}f'' + \cdots \implies$ الخطأ $= \frac{h}{2}f'' + O(h^2) = O(h)$. ■

- **النتيجة:** رتبة 1.
- **الربط بالذكاء الاصطناعي:** «تقريب المشتقّة بالفرق» = نواة SGD التقريبي (ch08).

مثال (11.5-2).

- **المعطيات:** الفرق المركزي $\frac{f(x+h)-f(x-h)}{2h}$.
- **المطلوب:** رتبة الخطأ.
- **الحل:**

١. الحدود الفردية تلغي؛ الخطأ $= -\frac{h^2}{6}f''' + \cdots = O(h^2)$. ■

- **النتيجة:** رتبة 2.
- **الربط بالذكاء الاصطناعي:** «الفرق المركزي أدقّ» — يُفضّل في المشتقّات العددية للخسائر.

مثال (11.5-3).

- **المعطيات:** اشتقاق مشتقّة عددية (tie) مع الفصل 8).
- **المطلوب:** اربط الفرق بـ تايلور.
- **الحل:**

١. كلّ صيغة فرق = قطع تايلور لمتعدّدة تلغي حدوداً. ■

- **النتيجة:** الفروق = تايلور مقصوص.
- **الربط بالذكاء الاصطناعي:** autodffi» أدقّ من الفرق» لأنه يتجنّب خطأ القطع هذا.

مثال (5.11-4).

- **المعطيات:** e^x مقطوعة عند n حدّ لـ $x = 1$.
- **المطلوب:** حدّ الخطأ.
- **الحل:**

١. $|R_n| \le e/(n+1)!$. لـ $n = 5$: $e/720 \approx 0.0038$. ■

- **النتيجة:** ≤ 0.0038.
- **الربط بالذكاء الاصطناعي:** «عدد الحدود لدقّة» — يشبه عرض النطاق لاكتساب النموذج.

مثال (5.11-5).

- **المعطيات:** نريد خطأ $< 10^{-4}$ لـ e^1.
- **المطلوب:** أوجد n من (11.4).
- **الحل:**

١. $e/(n+1)! < 10^{-4} \Longrightarrow (n+1)! > 27180 \Longrightarrow n+1 \ge 8 \Longrightarrow n = 7$. ■

- **النتيجة:** $n = 7$.
- **الربط بالذكاء الاصطناعي:** «تسوية الدقّة بالترتيب» — مقايضة دقّة/حساب كلاسيكية.

مثال (5.11-6).

- **المعطيات:** $O(h^2)$ مقابل تقارب فعلي.
- **المطلوب:** ميز بينهما.
- **الحل:**

١. $O(h^2)$ يصف السلوك الحدّي؛ التقارب الفعلي يحتاج $h \to 0$ والثابت C معقول. ■

- **النتيجة:** وصفي vs وجودي.
- **الربط بالذكاء الاصطناعي:** «نظرية تقارب vs ممارسة» — SGD له حدّ $O(1/\sqrt{T})$ لكن الثابت يهمّ.

مثال (5.11-7).

- **المعطيات:** خطأ SGD بعد T خطوة $= O(1/\sqrt{T})$.

- **المطلوب:** اربطه بـ (4.11).
- **الحل:**

١. $h = 1/\sqrt{T} \Longrightarrow$ الخطأ $O(h)$ من رتبة أولى — تقارب بطيء لكن مضمون. ■

- **النتيجة:** رتبة نقصان $1/2$.
- **الربط بالذكاء الاصطناعي:** «لماذا نحتاج آلاف الخطوات» — تحليل عيّنات التحسين العشوائي.

مثال (11.5-8).

- **المعطيات:** خطأ Carlo Monte $= O(1/\sqrt{N})$.
- **المطلوب:** اشرح.
- **الحل:**

١. التباين $\sigma^2/N \Longrightarrow$ الانحراف المعياري $\propto 1/\sqrt{N}$. ■

- **النتيجة:** نقصان جذري.
- **الربط بالذكاء الاصطناعي:** «كم عيّنة نحتاج؟» — أساس حجم الدُفعة (batch) والتقدير التجريبي.

مثال (11.5-9).

- **المعطيات:** استقراء ريتشاردسون (Richardson) من صيغتين بترتيب h^p.
- **المطلوب:** كيف يرفع الرتبة؟
- **الحل:**

١. $A(h) = A + ch^p + \ldots$، $A(2h) = A + c2^p h^p + \ldots \Longrightarrow$ دمجهما يلغي $h^p \Longrightarrow$ رتبة $2p$. ■

- **النتيجة:** مضاعفة الرتبة.
- **الربط بالذكاء الاصطناعي:** «تجميع تقديرات» لرفع الدقّة — مثل ensemble. models

مثال (11.5-10).

- **المعطيات:** طريقة أويلر $y_{n+1} = y_n + hf$ محلياً.
- **المطلوب:** رتبة الخطأ المحلّي.
- **الحل:**

١. من تايلور الحلّ: الخطأ المحلي $O(h^2)$ (عالمياً $O(h)$). ■

- **النتيجة:** محليّ رتبة 2.
- **الربط بالذكاء الاصطناعي:** «خطوة تكامل «ODE = أساس حلّ معادلات الانتشار (dffiusion SDE).

مثال (11-5.11).

- **المعطيات:** شبكة فرق (stencil) من 5 نقاط.
- **المطلوب:** رتبتها.
- **الحل:**

١. تلغي حدوداً حتى $h^4 \implies$ خطأ $O(h^4)$ للمشتقّة الثانية. ■

- **النتيجة:** رتبة 4.
- **الربط بالذكاء الاصطناعي:** «نواة التفاف أوسع = دقّة أعلى» — مقايضة في CNN.

مثال (12-5.11).

- **المعطيات:** قاعدة شبه المنحرف للتكامل.
- **المطلوب:** رتبة الخطأ.
- **الحل:**

١. من تايلور: الخطأ الكلّي $O(h^2)$ (للدالة ناعمة). ■

- **النتيجة:** رتبة 2.
- **الربط بالذكاء الاصطناعي:** «تقريب التوقّع بجمع» — كلّ تقدير متوسّط هو تكامل مقطوع.

مثال (13-5.11).

- **المعطيات:** تقريب الانتباه بمرتبة منخفضة (low-rank).
- **المطلوب:** اربطه بخطأ القطع.
- **الحل:**

١. اقتطاع قيم مفردات = قطع توسّع طيفي؛ الخطأ $\propto$ مجموع القيم المهملة. ■

- **النتيجة:** خطأ اقتطاع طيفي.
- **الربط بالذكاء الاصطناعي:** «تقليص الانتباه» (Linformer) = تقليل ترتيب التقريب لخفض التعقيد.

مثال (14-5.11).

- **المعطيات:** نموذج انحدار تلقائي (AR) بترتيب p.
- **المطلوب:** ما علاقة الترتيب بالخطأ؟
- **الحل:**

١. قطع التاريخ عند p يُهمل ذاكرة أقدم؛ الخطأ يخفضّ مع p ثمّ يشبع. ■

- **النتيجة:** رتبة محدودة.
- **الربط بالذكاء الاصطناعي:** «طول السياق» = رتبة التقريب — مقايضة ذاكرة/دقّة.

مثال (15-5.11).

- **المعطيات:** تعريف «رتبة p».
- **المطلوب:** صغه بدقّة.
- **الحل:**

١. $E = O(h^{p+1})$ يعني $|E| \le C|h|^{p+1}$ لـ h صغير. ■

- **النتيجة:** رتبة p $\Longrightarrow$ خطأ $(p+1)$.
- **الربط بالذكاء الاصطناعي:** «فهم الرتبة» ضروري لتحليل كلّ خوارزمية تقريب في ML.

التعريف

dir="ltr"> <div
,δx within known is x If **number)، condition & propagation (Error 1.6.11 Definition**
dffierentiable: f for then

$$\delta f \approx |f'(x)|\,\delta x.$$

is x at f of **number condition** (relative) The

$$\kappa(x) = \left|\frac{x\,f'(x)}{f(x)}\right|, \qquad \frac{|\delta f|}{|f|} \le \kappa(x)\,\frac{|\delta x|}{|x|}. \tag{5.11}$$

dir="ltr"> <div
.$\delta f \le \|\mathbf{J}_f\|\,\|\delta\mathbf{x}\|$ variables, several In

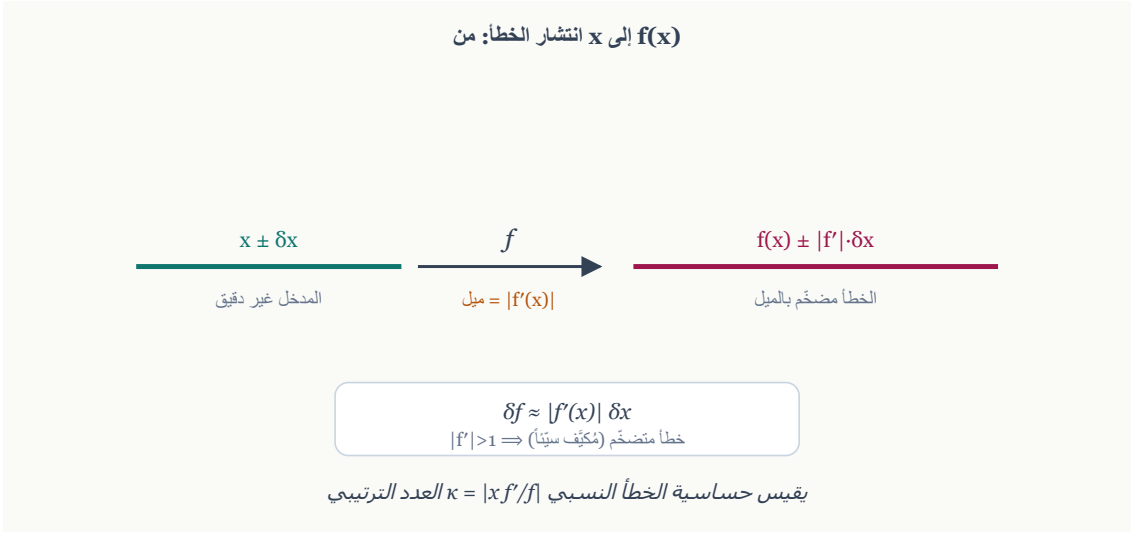
النظرية 1.6.11 (التكيّف السيّئ): $1 \quad \gg \quad \kappa$ يعني تضخّماً هائلاً للخطأ النسبي — مشكلة مُكيَّفة سيّئاً (ill-conditioned)، وترتبط بقيم مفردات كبيرة للهِسّية/المصفوفة.

جدول الرموز

الرمز	الاسم	المعنى
δf	خطأ المخرج	ينتج عن δx
κ	عدد التكيّف	مضخّم الخطأ النسبي
$\|\|J\|\|$	نُرم اليعقوبية	حدّ انتشار الخطأ المتجهي

رسم توضيحي

<figure> الشكل<figcaption>5.11: خطأ في المدخل $x \pm \delta x$ يمرّ عبر f فيصبح $f(x) \pm |f'(x)|\delta x$. إذا كان



شكل ٥.١١: *
انتشار الخطأ عبر f

$|f'| > 1$ (أو $\kappa \gg 1$) يتضخّم الخطأ — «تكيّف سيّئ».</figcaption></figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط الخطأ المطلق بالنسبي	تكيّف يقيس النسبي	استخدم $\delta f/\|f\|$
نسيان أنّ κ محلّي	يختلف بـ x	قيّم عند نقطة العمل
اعتبار f سلسة كافية	القفزات تكسر التحليل	افحص الاستمرارية
إهمال تراكم الطبقات	كلّ طبقة تضرب κ	$\kappa_{\text{net}} \approx \prod \kappa_i$

أمثلة محلولة على انتشار الخطأ والتكيّف (15 مثالاً)

مثال (1-6.11).

- **المعطيات:** $f(x, y) = x + y$، خطأ كلاهما δ.
- **المطلوب:** خطأ المجموع.
- **الحل:**

١. $|\partial_x| + |\partial_y|$ كلاهما 1 $\Longrightarrow \delta f \leq \delta + \delta = 2\delta$. $\delta f \approx$ ■

- **النتيجة:** مجموع الأخطاء المطلقة.
- **الربط بالذكاء الاصطناعي:** «تراكم خطأ الجمع» — يحدّ دقّة جمع الاحتمالات.

مثال (11.6-2).

- **المعطيات:** $f = xy$، خطأ نسبي $\varepsilon_x, \varepsilon_y$.
- **المطلوب:** خطأ نسبي للمُنتَج.
- **الحل:**

١. $\varepsilon_f \approx \varepsilon_x + \varepsilon_y \Longrightarrow \frac{\delta f}{|f|} \approx \frac{\delta x}{x} + \frac{\delta y}{y}$. ■

- **النتيجة:** تجميع نسبي.
- **الربط بالذكاء الاصطناعي:** «خطأ مُنتَج الطبقات» = مجموع أخطاء الأوزان — يفسّر تراكمها.

مثال (11.6-3).

- **المعطيات:** $f(x) = x^p$.
- **المطلوب:** $\kappa(x)$.
- **الحل:**

١. $f' = px^{p-1}$؛ $\kappa = |x \cdot px^{p-1}/x^p| = |p|$. ■

- **النتيجة:** $\kappa = |p|$ (مستقلّ عن x!).
- **الربط بالذكاء الاصطناعي:** «رفع القوة» له تكيّف $|p|$ — يفسّر حساسية ReLU^p والميزات التربيعية.

مثال (11.6-4).

- **المعطيات:** $f(x) = e^x$.
- **المطلوب:** التكيّف.
- **الحل:**

١. $\kappa = |xe^x/e^x| = |x|$. قرب الصفر مُكيَّف جيّداً، لـ x كبيرة سيّئ. ■

- **النتيجة:** $\kappa = |x|$.
- **الربط بالذكاء الاصطناعي:** exp» كبير مُكيَّف سيّئاً» — سبب log-sum-exp (ch06) لتفادي الانفجار.

مثال (11.6-5).

- **المعطيات:** $f(x) = 1 - \cos x$ لـ x صغير.
- **المطلوب:** لماذا خطير؟ (tie مع ch06)
- **الحل:**

١. $1 - \cos x \approx x^2/2 \implies$ طرح متقاربين = إلغاء كارثي. استخدم الصيغة المربّعة. ■

- **النتيجة:** تكيّف سيّئ محليّ.
- **الربط بالذكاء الاصطناعي:** «الإلغاء الكارثي» يظهر في خسارة المسافة والزوايا — تجنّبه بالصيغ المربّعة.

مثال (11.6-6).

- **المعطيات:** $f = x/y$.
- **المطلوب:** خطأ نسبي.
- **الحل:**

١. $\varepsilon_f \approx \varepsilon_x + \varepsilon_y$. ■

- **النتيجة:** تجميع كالمُنتَج.
- **الربط بالذكاء الاصطناعي:** «قسمة الاحتمالات» (مثل بايز) يجمع أخطاء البسط والمقام.

مثال (11.6-7).

- **المعطيات:** $f(x) = A^{-1}b$، خطأ في A.
- **المطلوب:** اربط بـ $\kappa(A)$ (tie مع ch05).
- **الحل:**

١. $\frac{\|\delta x\|}{\|x\|} \le \kappa(A)\frac{\|\delta A\|}{\|A\|}$، $\kappa = \|A\|\|A^{-1}\|$. ■

- **النتيجة:** تكيّف المصفوفة.
- **الربط بالذكاء الاصطناعي:** «انهيار عكس المصفوفة» — يفسّر عدم استقرار least squares سيّئ التكيّف.

مثال (11.6-8).

- **المعطيات:** شبكة بـ L طبقة، كل طبقة κ_i.
- **المطلوب:** تكيّف الشبكة.
- **الحل:**

١. $\kappa_{\text{net}} \approx \prod_{i=1}^{L} \kappa_i$ (تقريباً). ■

- **النتيجة:** تضخّم مضروب.
- **الربط بالذكاء الاصطناعي:** «لماذا الشبكات العميقة هشّة» — تراكم التكيّف عبر الطبقات.

مثال (11.6-9).

- **المعطيات:** قارن خطأً مطلقاً (10^{-3}) ونسبياً.
- **المطلوب:** متى النسبي أهمّ؟
- **الحل:**

١. إذا $|f| = 10^{-6}$ فخطأ 10^{-3} = نسبي 10^{3} (كارثي)؛ مطلقاً صغير. ■

- **النتيجة:** النسبي يصف الحجم.
- **الربط بالذكاء الاصطناعي:** «خطأ نسبي في الاحتمالات الصغيرة» — أساس تقييم الاحتمالات النادرة.

مثال (11.6-10).

- **المعطيات:** انتشار التباين $\text{Var}(f(X))$.
- **المطلوب:** قرّبه بتايلور من الدرجة الأولى.
- **الحل:**

١. $f(X) \approx f(\mu) + f'(\mu)(X-\mu) \Longrightarrow \text{Var} \approx [f'(\mu)]^2 \,\text{Var}(X)$. ■

- **النتيجة:** تباين منتشر خطّياً.
- **الربط بالذكاء الاصطناعي:** «انتشار عدم اليقين» (propagation) — أساس بايز التقريبي وقياس الثقة.

مثال (11.6-11).

- **المعطيات:** $f(x) = \log x$.
- **المطلوب:** هل اللوغاريتم يُثبّت؟

- **الحل:**

١. $\kappa = |x \cdot (1/x)/\log x| = |1/\log x|$، كبيرًا لـ $x \approx 1$ لكنه يضبط مقاييس واسعة. ■

- **النتيجة:** يضبط النطاقات.

- **الربط بالذكاء الاصطناعي:** «تحويل لوغاريتمي» يُثبّت التباين عبر المقاييس — شائع في المعالجة.

مثال (11.6-12).

- **المعطيات:** $f(x) = \text{softmax}(x)_i$.

- **المطلوب:** التكيّف حول قيم كبيرة.

- **الحل:**

١. المشتقّة $p_i(1-p_i) \leq 1/4 =$؛ مُكيَّف جيّداً محليّاً. ■

- **النتيجة:** مستقرّ.

- **الربط بالذكاء الاصطناعي:** softmax» مُكيَّف جيّداً» — سبب استقراره مقابل exp مباشر.

مثال (11.6-13).

- **المعطيات:** تدرّجات تتلاشى/تنفجر في شبكة عميقة.

- **المطلوب:** اربط بالتكيّف.

- **الحل:**

١. $\|\mathbf{J}_{\text{net}}\| \approx \prod \|W_i\|$؛ إن كانت $1 >$ تنفجر، $1 <$ تتلاشى. ■

- **النتيجة:** تكيّف مضروب = مشكلة التدرّج.

- **الربط بالذكاء الاصطناعي:** «انفجار/تلاشي التدرّج» — حلوله (Batchnorm, residual) تخفض التكيّف المضروب.

مثال (11.6-14).

- **المعطيات:** $f : \mathbb{R}^d \to \mathbb{R}^m$، δx صغير.

- **المطلوب:** حدّ الخطأ.

- **الحل:**

١. $\|\delta f\| \leq \|J_f\| \, \|\delta x\|$ (نُرم المصفوفة). ■

- **النتيجة:** اليعقوبية تضبط الانتشار.

- **الربط بالذكاء الاصطناعي:** «نُرم اليعقوبية = استقرار الشبكة» — يقاس في تحليل حساسية النموذج.

مثال (15-6.11).

- **المعطيات:** صيغة $\kappa = |xf'/f|$.
- **المطلوب:** طبّقها على $f(x) = x$ نفسها.
- **الحل:**

١. $\kappa = |x \cdot 1/x| = 1$ دائماً — الهوية مُكيَّفة تماماً. ■

- **النتيجة:** المرجع المعياري.
- **الربط بالذكاء الاصطناعي:** «المقارنة بـ $\kappa = 1$» تُقيّم جودة تكيّف أيّ دالة.

النظريات والصيغ

dir="ltr"> <div
is step Newton the ,f minimizing For **Gauss-Newton). & (Newton 1.7.11 Theorem**

$$\mathbf{x}_{k+1} = \mathbf{x}_k - H_f^{-1} \nabla f(\mathbf{x}_k).$$

Gauss-Newton the by approximated is Hessian the ,$\frac{1}{2}\|r(\mathbf{x})\|^2$ squares least nonlinear For
:$J_r^\top J_r$ matrix

$$\mathbf{x}_{k+1} = \mathbf{x}_k - (J_r^\top J_r)^{-1} J_r^\top r.$$

$$\text{Newton:} x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)} \quad (1\text{-D}); \qquad \text{GN:} J^\top J\,\delta = -J^\top r. \tag{6.11}$$

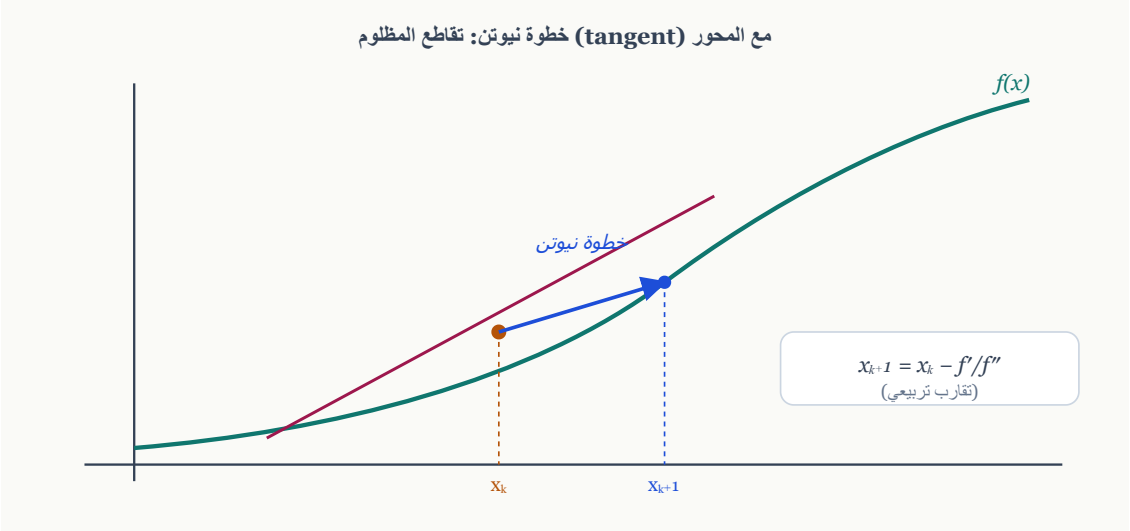
النظرية 1.7.11 (التفاضل الآلي): backprop يحسب ∇f و $\nabla^2 f$ (أو منتجاتها بأشعة) **بدقّة رياضية** — أيّه يُنتج معاملات تايلور دون خطأ قطع.

جدول الرموز

الرمز	الاسم	المعنى
H_f	هِسّية الهدف	انحناء دالة الخسارة
J_r	يعقوبية المتبقّي	مشتقّات الأخطاء
GN	غاوس-نيوتن	تقريب هِسّية بـ $J^\top J$

رسم توضيحي

<figure> الشكل<figcaption> 6.11: نيوتن يأخذ خطوة نحو جذر المظلوم (tangent) عند x_k؛ النتيجة x_{k+1}. عند تقارب جيّد يصل تربيعياً (أسرع من التدرّج).</figcaption>/ </figure>



شكل ٦٠١١: *
خطوة نيوتن على منحنى محدّب

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
استخدام نيوتن عند هِسّية غير موجبة	قد يصعد لا ينزل	أضف تنعيم Levenberg–Marquardt/
اعتبار GN = هِسّية حقيقية	هي تقريب	صالحة قرب المُثلّث فقط
نسيان تكلفة عكس H	$O(d^3)$	استخدم تقريبات (K-FAC/Shampoo)
الخلط بين تدرّج ونيوتن	سرعة تقارب مختلفة	تدرّج $O(1/k)$، نيوتن تربيعي

أمثلة محلولة على تطبيقات الذكاء الاصطناعي (15 مثالاً)

مثال (11.7-1).

- **المعطيات:** نيوتن على $f(x) = x^2 - 2$ لإيجاد $\sqrt{2}$.
- **المطلوب:** خطوة من $x_0 = 1$.
- **الحل:**

١. $f' = 2x,\ f'' = 2$؛ الكسر $x_1 = 1 - (2-2)/2 = 1$؟ $\Longrightarrow (x^2-2)/(2x) = (1-2)/2 = -0.5$
$x_1 = 1 - (-0.5) = 1.5$.

٢. $x_2 = 1.5 - (0.25/3) = 1.4167$. ■

- **النتيجة:** تقارب سريع نحو 1.4142.
- **الربط بالذكاء الاصطناعي:** «نيوتن تربيعي» — نموذج لسرعة التحسين من الدرجة الثانية.

مثال (11.7-2).

- **المعطيات:** خسارة لوجستيك أحادية $\ell(w)$.
- **المطلوب:** خطوة نيوتن.
- **الحل:**

١. $\ell' = p - y$، $\ell'' = p(1-p) > 0$؛ $w_{k+1} = w_k - (p-y)/(p(1-p))$. ■

- **النتيجة:** خطوة مضبوطة باليقين.
- **الربط بالذكاء الاصطناعي:** «نيوتن-لوجستيك» يتقارب في خطوات قليلة — أسرع من SGD.

مثال (11.7-3).

- **المعطيات:** مربعات صغرى غير خطّية $r_i(x)$.
- **المطلوب:** خطوة غاوس-نيوتن.
- **الحل:**

١. $J^\top J\,\delta = -J^\top r$؛ الحلّ δ ثمّ $x \leftarrow x + \delta$. ■

- **النتيجة:** تقارب محليّ سريع.
- **الربط بالذكاء الاصطناعي:** «Gauss-Newton» = أساس خوارزميات الملاءمة (curve fitting، bundle adjustment).

مثال (11.7-4).

- **المعطيات:** تحت أيّ شرط تقارب نيوتن تربيعياً؟
- **الحل:**

١. قرب جذر بـ f'' مستمرّة غير صفرية $\Rightarrow |e_{k+1}| \le C|e_k|^2$ (تربيعي). ■

- **النتيجة:** تقارب تربيعي محليّ.
- **الربط بالذكاء الاصطناعي:** «لماذا Adam لا يصل بسرعة نيوتن» — الفرق في الرتبة.

مثال (11.7-5).

- **المعطيات:** شبكة بـ backprop.
- **المطلوب:** كيف يحسب معاملات تايلور؟
- **الحل:**

١. قاعدة السلسلة (ch09) تحسب ∇ بدقّة؛ تفاضل من الدرجة الثانية (reverse-mode) يحسب منتجات Hv. ■

- **النتيجة:** تايلور بدون خطأ قطع.
- **الربط بالذكاء الاصطناعي:** autodiff» = تايلور دقيق» — يتفوّق على الفروق المنتهية (11.5-3).

مثال (11.7-6).

- **المعطيات:** التدرّج الطبيعي (Natural Gradient).
- **المطلوب:** اربطه بتايلور على فضاء Riemannian.
- **الحل:**

١. التقريب التربيعي يُقاس بـ مصفوفة المعلومات F؛ الخطوة $\tilde{\nabla} = F^{-1}\nabla$. ■

- **النتيجة:** نيوتن على فضاء المعاملات.
- **الربط بالذكاء الاصطناعي:** «Natural gradient» يُثبّت التكيّف عبر هندسة فيشر (الفصل 29 لاحقاً).

مثال (11.7-7).

- **المعطيات:** تحديث لانغفين $x_{k+1} = x_k - \eta \nabla U(x_k) + \sqrt{2\eta}\,\xi$.
- **المطلوب:** ما دور تايلور؟
- **الحل:**

١. ∇U هو الدرجة الأولى من تايلور لـ U؛ التحديث يسير نحو الحوض. ■

- **النتيجة:** مشي عشوائي موجّه بالتدرّج.
- **الربط بالذكاء الاصطناعي:** «Langevin MCMC» — أساس أخذ العيّنات من التوزيعات (وطالب dffiusion).

مثال (11.7-8).

- **المعطيات:** مطابقة السكور (Score matching).
- **المطلوب:** اربط بتايلور/المشتقّات.
- **الحل:**

١. السكور $\nabla_x \log p(x)$ هو الدرجة الأولى؛ المطابقة تُقرّب p عبر تطابق تباين السكور. ■

- **النتيجة:** تعلّم بلا عينات سلبية.
- **الربط بالذكاء الاصطناعي:** «Score-based models» — أساس dffiusion الحديث (مشتقّة لوغ-كثافة).

مثال (11.7-9).

- **المعطيات:** محسّنات من الدرجة الثانية (K-FAC, Shampoo).
- **المطلوب:** ماذا تقرّب؟
- **الحل:**

١. تقرّب H^{-1} بعوامل كرونيكرية/كتل لتفادي عكس $d \times d$ كامل. ■

- **نتيجة:** نيوتن عمليّ.
- **الربط بالذكاء الاصطناعي:** «نيوتن قابل للتطوير» — يقرّب الهِسّية بدل حسابها كاملة.

مثال (11.7-10).

- **المعطيات:** تدرّج السياسة (Policy Gradient).
- **المطلوب:** اربط بتايلور للمكافأة.
- **الحل:**

١. تغيير السياسة $\nabla_\theta J \approx \int \nabla_\theta \pi(a|s) Q \, d\tau$ = معامل تايلور الأول للعائد. ■

- **النتيجة:** تدرّج من الدرجة الأولى.
- **الربط بالذكاء الاصطناعي:** «PG = مشتقّة العائد» — كلّ RL يعتمد على تايلور من الدرجة الأولى.

مثال (11.7-11).

- **المعطيات:** نواة التماس العصبية (NTK).
- **المطلوب:** ما دور التقريب الخطّي؟
- **الحل:**

١. عند العرض اللانهائي، $f(\theta) \approx f(\theta_0) + J_{\theta_0}(\theta - \theta_0)$ — تايلور من الدرجة الأولى يُثبت تجمّد التدريب. ■

- **النتيجة:** خطّي حول التهيئة.
- **الربط بالذكاء الاصطناعي:** «NTK» (الفصل 40) يفسّر لماذا الشبكات العميقة تتعلّم كنواة — عبر تايلور.

مثال (11.7-12).

- **المعطيات:** مبرهنة Tweedie في dffiusion.
- **المطلوب:** اربط بتايلور.
- **الحل:**

١. $\mathbb{E}[x_0|x_t] = \frac{1}{\sigma_t^2}(x_t + \sigma_t^2 \nabla_{x_t} \log p_t(x_t))$ — السكور من الدرجة الأولى يصلح المتوسّط. ■

- **النتيجة:** إزالة الضجيج بتايلور.
- **الربط بالذكاء الاصطناعي:** «Tweedie» = «السكور» — قلب عينة dffiusion (الفصل 41).

مثال (11.7-13).

- **المعطيات:** Adam كمحسّن من الدرجة الأولى.
- **المطلوب:** لماذا ليس نيوتن؟
- **الحل:**

١. Adam يستخدم لحظات التدرّج (درجة أولى) فقط؛ لا هِسّية $\Longrightarrow$ أبطأ لكن أرخص بكثير. ■

- **النتيجة:** تريدو/آدم = تايلور درجة 1.
- **الربط بالذكاء الاصطناعي:** «العمليّة تغلب الكمال» — Adam هو المعيار رغم بطئه النظري.

مثال (11.7-14).

- **المعطيات:** حادّة النموذج (sharpness) عبر الهِسّية.
- **المطلوب:** كيف تُقاس؟
- **الحل:**

١. $\lambda_{\max}(\nabla^2 \ell)$ = أعلى انحناء؛ حادّة عالية $\perp$ تعميم ضعيف غالباً. ■

- **النتيجة:** مؤشّر تعميم.
- **الربط بالذكاء الاصطناعي:** «تسطيح المشهد» (Sharpness-Aware Minimization) يحسّن التعميم عبر الهِسّية.

مثال (11.7-15).

- **المعطيات:** تقريب غاوس-نيوتن $H \approx J^\top J$.
- **المطلوب:** متى يساوي الهِسّية الحقيقية؟
- **الحل:**

١. $H = J^\top J + \sum r_i \nabla^2 r_i$؛ إن كانت الأخطاء $r_i \approx 0$ (قرب المُثلّث) يتطابقان. ■

- **النتيجة:** GN صالح قرب الحلّ.
- **الربط بالذكاء الاصطناعي:** «لماذا GN مستقرّ» — لـ $J^\top J$ شبه موجبة دائماً (لا انعكاس مفسد).

خيط الفصل

١. **متعدّدات تايلور (2.11)** تحوّل أيّ دالة ناعمة إلى متعدّدة حدود محليّاً — أساس كلّ تقريب عددي.

٢. **البقايا (3.11)** تضبط «حجم الخطأ» بعد القطع — لاغرانج للحدّ الأعلى، التكاملية للبرهان، بيانو للسرعة.

٣. **تايلور المتعدّد (4.11)** يُدخل الهِسّية $\nabla^2 f$ — الانحناء الذي يفرق بين حوض وسرج.

٤. **خطأ القطع (5.11)** يمنحنا لغة «الرتبة» $O(h^{p+1})$ — توازن دقّة/تكلفة في كلّ خوارزمية.

٥. **انتشار الخطأ (6.11)** يحوّل الخطأ إلى «تكيّف» κ — يفسّر انفجار/تلاشي التدرّج.

٦. **التطبيقات (7.11)** تجمع الكلّ: نيوتن = تايلور درجة 2، autodiff = معاملات دقيقة، dffiusion/Tweedie = سكور من الدرجة الأولى.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
∇, ∇^2 من تايلور	التحسين (الفصل 20+)
بقايا وخطأ القطع	تحليل تقارب SGD/MCMC
تكيّف κ	الاستقرار العددي، العكس
Gauss-Newton	ملاءمة غير خطّية، adjustment bundle
السكور $\nabla \log p$	matching score dffiusion،
خطّي/NTK حول التهيئة	نظرية الشبكات العميقة (الفصل 40)

١. اكتب $P_4(x)$ لـ $f(x) = \cos x$ حول 0 وحدّد نصف القطر.

٢. أثبت $e^x = \sum x^k/k!$ عبر تايلور (حول 0) وحدّد التقارب.

٣. لـ $f(x) = \ln(1+x)$، أوجد $R_3(0.5)$ بصيغة لاغرانج.

٤. قرّب $\sqrt{1.05}$ بدرجة 2 وقدّر الخطأ بـ (2.11).

٥. عرّف $\kappa(x)$ وأثبت أنّ $f(x) = x^p$ لها $\kappa = |p|$ لـ $x > 0$.

٦. أثبت أنّ الفرق المركزي رتبته $O(h^2)$ عبر تايلور.

٧. لـ $f(x,y)=x^2-y^2$، احسب ∇ و ∇^2 وصنّف النقطة $(0,0)$.

٨. اشتقّ خطوة نيوتن $h=-H^{-1}\nabla$ من التقريب التربيعي.

٩. لـ $f(x)=e^x$ عند $x=10$، ما κ؟ ولماذا يُنصح بـ log-sum-exp؟

١٠. طبّق Gauss-Newton على $r(x)=[x-1,\ 2x-2]^\top$ من $x_0=0$.

١١. بيّن أنّ $f(x)=x_1^2+2x_1x_2+3x_2^2$ تربيعية تماماً (تايلور = الدالة).

١٢. حدّد رتبة خطأ قاعدة سيمبسون للتكامل.

١٣. باستقراء ريتشاردسون من صيغتين $O(h^2)$، ما الرتبة الناتجة؟

١٤. لـ $f(x)=A^{-1}b$، أثبت $\frac{\|\delta x\|}{\|x\|}\le\kappa(A)\frac{\|\delta A\|}{\|A\|}$.

١٥. اربط انفجار التدرّج بـ $\prod\|W_i\|$ واقترح حلاً (Batchnorm/Residual).

١٦. أثبت أنّ Δf يظهر كمجموع الانحناءات الاتجاهية (عبر تايلور).

١٧. لـ softmax، logit احسب ∇ و ∇^2 (كنتيجة 4.11-12).

١٨. بيّن أنّ GN موجبة شبه-معرّفة دائماً (لـ $J^\top J$).

١٩. عبّر مبرهنة Tweedie $\mathbb{E}[x_0|x_t]$ بالسكور واربطها بتايلور درجة أولى.

٢٠. تحدٍّ تركيبي: «لماذا أخذ عيّنات Carlo Monte بطيء؟» — اشتقّ $O(1/\sqrt{N})$ من تايلور/تباين، واربطه بخطأ SGD $O(1/\sqrt{T})$، ثمّ ناقش كيف ترفع رتبة (5.11-9) الدقّة.

- **تايلور (1.11):** $P_n(x)=\sum f^{(k)}(a)(x-a)^k/k!$ — تقريب محليّ للدالة الناعمة.
- **البقايا (2.11):** لاغرانج $|R_n|\le M|x-a|^{n+1}/(n+1)!$؛ صيغ تكاملية/بيانو مكمّلة.
- **متعدّد (3.11):** $f(x+h)=f+\nabla^\top h+\frac12 h^\top\nabla^2 f\,h+R_2$ — الهِسّية تحكم الانحناء.
- **خطأ القطع (4.11):** رتبة p تعني $O(h^{p+1})$؛ الفروق المركزية أدقّ من الأمامية.
- **التكيّف (5.11):** $\kappa=|xf'/f|$ يقيس تضخّم الخطأ النسبي؛ $\kappa\gg1$ = مُكيَّف سيّئاً.
- **التطبيقات (6.11):** نيوتن $x-f'/f''$ (تربيعي)؛ Gauss-Newton يقرّب $H\approx J^\top J$؛ autodiff يُنتج معاملات دقيقة؛ Tweedie/score يستخدم السكور من الدرجة الأولى.

الرمز	المعنى	أين عُرّف
P_n	متعدّدة تايلور	(1.11)
R_n	البقايا	(2.11)
$\nabla^2 f$	الهِسّية	(3.11)
$O(h^{p+1})$	رتبة الخطأ	(4.11)
$\kappa(x)$	عدد التكيّف	(5.11)
$J_r^\top J_r$	تقريب GN	(6.11)

١. J. Stewart, (2015). *Calculus*, 8th ed., Cengage — تايلور والبقايا بشكل كلاسيكي.

٢. T. Apostol, (1967). *Calculus, Vol. I*, Wiley — أساس نظري صارم للتوسّعات.

٣. N. Higham, (2002). *Accuracy and Stability of Numerical Algorithms*, 2nd ed., SIAM — تحليل الخطأ والتكيّف (يرتبط بـ ch06).

٤. S. Wright, & J. Nocedal, (2006). *Numerical Optimization*, 2nd ed., Springer — نيوتن/Gauss-Newton والتحسين من الدرجة الثانية.

٥. C. Bishop, (2006). *Pattern Recognition and Machine Learning*, Springer — الهِسّية في التصنيف والتقريب اللاخطي.

٦. I., Goodfellow, A. Courville, & Y. Bengio, (2016). *Deep Learning*, MIT Press — التدرّج، تلاشي/انفجار التدرّج، والتحسين.

٧. L., Bottou, F. Curtis, & J. Nocedal, (2018). *Optimization Methods for Large-Scale Machine Learning*, SIAM Review — تحليل عيّنات SGD ($O(1/\sqrt{T})$).

٨. A., Jacot, F. Gabriel, & C. Hongler, (2018). *Neural Tangent Kernel* (NeurIPS) — تخطيط الشبكة كتايلور خطّي عند العرض اللانهائي.

٩. S. Ermon, & Y. Song, (2019). *Generative Modeling by Estimating Gradients of the data distribution* (score matching/dffiusion) — استخدام السكور ($\nabla \log p$) في التوليد.

المعادلات التفاضلية والنظم الديناميكية

الهدف من الفصل

سادس وأخير فصول الجزء الثاني (التفاضل والتكامل). أنهينا النهايات (7) والمشتقّة (8) والتفاضل المصفوفي (9) والتكامل/القياس (10) وتايلور/الأخطاء (11). الآن نربط الاشتقاق بـ «الزمن»: كيف تتطوّر الكميات؟ المعادلات التفاضلية هي لغة التدفّق — وتعلّم الآلة كلّه نظام ديناميكي: التدريب = تدفّق تدرّجي، وdffiusion = حلّ معادلة تفاضلية عشوائية (SDE) عكسية.

أربعة أسباب تجعل هذا الفصل «بوّابة» نحو الجزء الثالث وما بعده:

١. **التدريب نظام ديناميكي:** نزول التدرّج $\theta_{t+1} = \theta_t - \eta \nabla L$ هو تdiscret (تقطيع) للمعادلة المستمرّة $\dot{\theta} = -\nabla L(\theta)$ — «تدفّق تدرّجي».

٢. **الاستقرار والتقارب:** تحليل النقاط الثابتة (fixed points) وأحواض الجذب يفسّر لماذا يتقارب النموذج ولماذا قد يعلق في سرج.

٣. **المعادلات الجزئية (PDE):** الانتشار (dffiusion) = معادلة حرارية؛ أساس نماذج التوليد الحديثة.

٤. **الأنظمة العشوائية:** dffiusion و Langevin و SDE هي «تفاضلية + ضجيج» — الجسر إلى الاحتمالات (الجزء الثالث).

خريطة الفصل

القسم	الموضوع	الأداة المركزية
2.12	المعادلات التفاضلية العادية (ODE)	$\dot{x} = f(t, x)$
3.12	الطرق العددية: أويلر وروبج-كوتا	$x_{n+1} = x_n + h\dot{x}_n$
4.12	التحليل الكيفي: النقاط الثابتة والاستقرار	$J = \nabla f(x^*)$
5.12	المعادلات التفاضلية الجزئية (PDE)	$\partial_t u = \alpha \nabla^2 u$
6.12	النظم الديناميكية والتعلّم	$\dot{\theta} = -\nabla L$
7.12	التطبيقات الحديثة: ODE Neural و Dffiusion/SDE	SDE عكسي

التعريف

dir="ltr"> <div

Definition 1.2.12 (Initial Value Problem). An ODE with initial condition is $\dot{x} = f(t, x), \quad x(t_0) = x_0,$ where $\dot{x} = dx/dt$. If f does not depend on t it is **autonomous**.

Theorem. Picard–Lindelöf. If f is continuous in t and **Lipschitz** in x on a neighbourhood, there exists a unique local solution.

$$\dot{x} = f(t, x), \quad x(t_0) = x_0. \tag{1.12}$$

النظرية 1.2.12 (صيغ خاصّة):

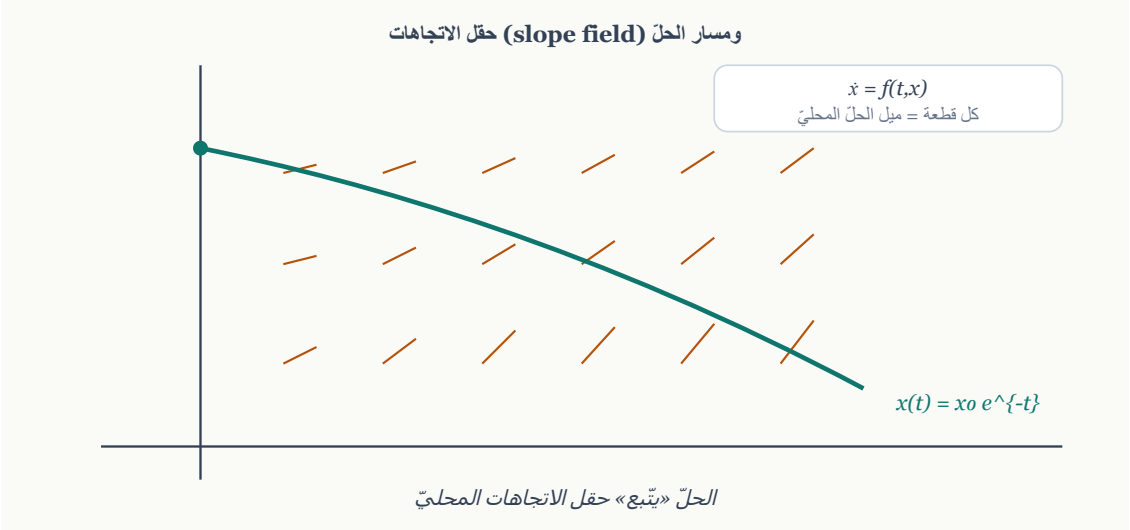
- **قابلة للفصل:** $\frac{dy}{dx} = \frac{g(x)}{h(y)} \Longrightarrow \int h(y)dy = \int g(x)dx$.
- **خطّية من الدرجة الأولى:** $\dot{x} + p(t)x = q(t)$ تُحلّ بعامل التكامل $e^{\int p}$.

جدول الرموز

الرمز	الاسم	المعنى
$\dot{x}$	المشتقّة الزمنية	dx/dt
f	الحقل الاتجاهي	يحدّد «الميل» المحلّي
Lipschitz	شرط انتظام	يضمن الوحيدة

رسم توضيحي

<figure> الشكل<figcaption> 1.12: الحلّ $x(t)$ «يتّبع» حقل الاتجاهات — عند كل نقطة الميل معطى بـ



شكل ١٠١٢: *
حقل اتجاهات ومسار حلّ

$f(t,x)$. الحلّ بمنحنى أخضر يبدأ من $(0, x_0)$ ويتبع الميل المحلّي.</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
نسيان شرط البداية	الحلّ غير محدّد بلا x_0	أرفق دائماً IVP
افتراض الوجود دائماً	قد لا يحلّ محلّياً	افحص الانتظام
تجاهل Lipschitz للوحيدة	قد تتعدّد الحلول	تحقّق Lipschitz
خلط مستقل/غير مستقل	$f(x)$ vs $f(t,x)$	صنّف النظام

أمثلة محلولة على المعادلات التفاضلية العادية (15 مثالاً)

مثال (12.2-1).

- **المعطيات:** $\dot{x} = kx$، $x(0) = x_0$.
- **المطلوب:** الحلّ.
- **الحل:**

١. $\frac{dx}{x} = k\,dt \Longrightarrow \ln|x| = kt + C \Longrightarrow x = x_0 e^{kt}$. ■

- **النتيجة:** نموّ/اضمحلال أسّي.
- **الربط بالذكاء الاصطناعي:** «ديناميكا معدّل ثابت» — نموذج لالتواء الاحتمالات ونصف أعمار الأوزان.

مثال (12.2-2).

- **المعطيات:** $\dot{x} = -kx$، $x(0) = 1$.
- **المطلوب:** الحلّ وسلوك $t \to \infty$.
- **الحل:**

١. $x = e^{-kt} \to 0$ لـ $t \to \infty$. ■

- **النتيجة:** اضمحلال.
- **الربط بالذكاء الاصطناعي:** «اضمحلال الوزن» (weight decay) = معادلة من الدرجة الأولى.

مثال (12.2-3).

- **المعطيات:** $\frac{dy}{dx} = \frac{y}{x}$، $y(1) = 2$.
- **المطلوب:** حلّ قابل للفصل.
- **الحل:**

١. $\frac{dy}{y} = \frac{dx}{x} \Longrightarrow \ln y = \ln x + C \Longrightarrow y = cx$؛ من $y(1) = 2$: $c = 2$. ■

- **النتيجة:** $y = 2x$.
- **الربط بالذكاء الاصطناعي:** «تناسب طردي» — أساس ميزات المقياس الخطّي.

مثال (12.2-4).

- **المعطيات:** لوجستيك $\dot{x} = rx(1 - x/K)$، $x(0) = x_0$.
- **المطلوب:** النقاط الثابتة وسلوكها.
- **الحل:**

١. الثوابت: $x = 0$ (غير مستقر)، $x = K$ (مستقر).

٢. الحلّ $x(t) = \frac{Kx_0e^{rt}}{K+x_0(e^{rt}-1)}$. ■

- **النتيجة:** تشبّع عند السعة K.
- **الربط بالذكاء الاصطناعي:** «تشبّع السعي» (sigmoid-like) — يظهر في ديناميكا الشبكات والسكان.

مثال (12.2-5).

- **المعطيات:** $\dot{x} + 2x = e^{-t}$، $x(0) = 0$.
- **المطلوب:** حلّ خطّي بعامل تكامل.
- **الحل:**

١. العامل e^{2t}؛ $(xe^{2t})' = e^t \implies xe^{2t} = e^t - 1 \implies x = e^{-t} - e^{-2t}$. ■

- **النتيجة:** ردّ انتقالي.
- **الربط بالذكاء الاصطناعي:** «استجابة عابرة» — نموذج لاستقرار المحسّن.

مثال (12.2-6).

- **المعطيات:** $\dot{x} = f(x)$ Lipschitz محليّاً، $x(t_0) = x_0$.
- **المطلوب:** ماذا يضمن بيكار-ليندلوف؟
- **الحل:**

١. وجود وحيدة محليّان للحلّ. ■

- **النتيجة:** حلّ فريد قريباً.
- **الربط بالذكاء الاصطناعي:** «تفاضل آلي يُعطي تدرّجاً فريداً» — أساس استقرار مسار التدريب.

مثال (12.2-7).

- **المعطيات:** $\dot{x} = x^{1/3}$، $x(0) = 0$.
- **المطلوب:** هل الحلّ فريد؟
- **الحل:**

١. $f'(0)$ غير منتهٍ $\Rightarrow$ غير Lipschitz عند 0؛ حلول $x = 0$ و $x = (\frac{2}{3}t)^{3/2}$ كلاهما يمرّ بـ 0. ■

- **النتيجة:** تعدّد الحلول — فقدان الوحيدة.
- **الربط بالذكاء الاصطناعي:** «نقاط غير ناعمة» تكسر التحليل — سبب تفضيل التنعيم (smoothing) في الخسائر.

مثال (12.2-8).

- **المعطيات:** مذبذب $\ddot{x} = -\omega^2 x$، $x(0) = A, \dot{x}(0) = 0$.
- **المطلوب:** الحلّ.
- **الحل:**

١. $x(t) = A\cos(\omega t)$. ■

- **النتيجة:** تذبذب دوريّ.
- **الربط بالذكاء الاصطناعي:** «ترددات/اهتزازات» — نموذج لديناميكا الاهتمام الدوري.

مثال (12.2-9).

- **المعطيات:** نظام $\dot{X} = AX$، $X(0) = X_0$.
- **المطلوب:** الحلّ.
- **الحل:**

١. $X(t) = e^{At}X_0$ (أسّ مصفوفي). ■

- **النتيجة:** أسّ مصفوفي.
- **الربط بالذكاء الاصطناعي:** «أسّ مصفوفي = تطوّر خطّي» — يظهر في النظم الديناميكية للشبكات.

مثال (12.2-10).

- **المعطيات:** مشكلة قيمة ابتدائية عامّة.
- **المطلوب:** لماذا البداية ضرورية؟
- **الحل:**

١. الحلّ العامّ يحوي ثوابت تعيين؛ $x(t_0)=x_0$ تحدّدها. ■

- **النتيجة:** بلا شرط بداية الحلّ غير فريد.
- **الربط بالذكاء الاصطناعي:** «التهيئة = شرط ابتدائي» — تحدّد مسار التدريب (NTK) يثبته عند العرض اللانهائي، ch11).

مثال (11-2.12).

- **المعطيات:** معادلة تامّة $M\,dx+N\,dy=0$ مع $\partial M/\partial y=\partial N/\partial x$.
- **المطلوب:** أوجد الدالّة الكمونية Φ.
- **الحل:**

١. $\Phi=\int M\,dx+\int(N-\Phi_y)\,dy$؛ المستويات $\Phi=c$ هي الحلول. ■

- **النتيجة:** منحنيات كمون.
- **الربط بالذكاء الاصطناعي:** «دالّة كمون» = أساس fields conservative والتدرّج من الدرجة الأولى.

مثال (12-2.12).

- **المعطيات:** برنولي $\dot{x}+px=qx^{n}$.
- **المطلوب:** اختزلها خطّية.
- **الحل:**

١. بـ $y=x^{1-n}$ تصبح خطّية. ■

- **النتيجة:** تحويل لخطّي.
- **الربط بالذكاء الاصطناعي:** «تحويل غير خطّي لخطّي» — نموذج لـ feature maps.

مثال (13-2.12).

- **المعطيات:** قارن مستقلّاً $f(x)$ وغير مستقلّ $f(t,x)$.

- **المطلوب:** أثر ذلك على التحليل.
- **الحل:**

١. المستقلّ له مخطّط طور ثابت؛ غير المستقلّ يتغيّر زمنياً. ■

- **النتيجة:** فرق في الاستقرار.
- **الربط بالذكاء الاصطناعي:** «معدّل تعلّم متغيّر زمنياً» (schedule) = نظام غير مستقلّ.

مثال (14-2.12).

- **المعطيات:** $\ddot{x} = f(t, x, \dot{x})$ من الدرجة الثانية.
- **المطلوب:** اختزالها نظاماً من الدرجة الأولى.
- **الحل:**

١. بـ $v = \dot{x}$: $\dot{x} = v,\ \dot{v} = f(t, x, v)$. ■

- **النتيجة:** نظام أبعاد 2.
- **الربط بالذكاء الاصطناعي:** «رفع المرتبة» = زيادة أبعاد الحالة — نمط في النماذج الديناميكية.

مثال (15-2.12).

- **المعطيات:** لماذا ODE في التعلّم؟
- **المطلوب:** اربط بالتدريب.
- **الحل:**

١. التحديث المنفصل $\theta_{k+1} = \theta_k - \eta \nabla L$ هو تقطيع أويلر (3.12) للمستمرّ $\dot{\theta} = -\nabla L$. ■

- **النتيجة:** GD = ODE مقطّعة.
- **الربط بالذكاء الاصطناعي:** «التدرّب كنظام ديناميكي» — خيط الفصل 6.12 بأكمله.

التعريف

dir="ltr"> <div
method: Euler explicit The **Runge–Kutta). & (Euler 1.3.12 Definition**

$$x_n + 1 = x_n + h\, f(t_n, x_n). \tag{2.12}$$

dir="ltr"> <div
has and step per evaluations slope four uses (RK4) Runge–Kutta 4th-order classical The
$O(h^4)$ global ,$O(h^5)$ error local has Euler $O(h^2)$ global ,$O(h)$.

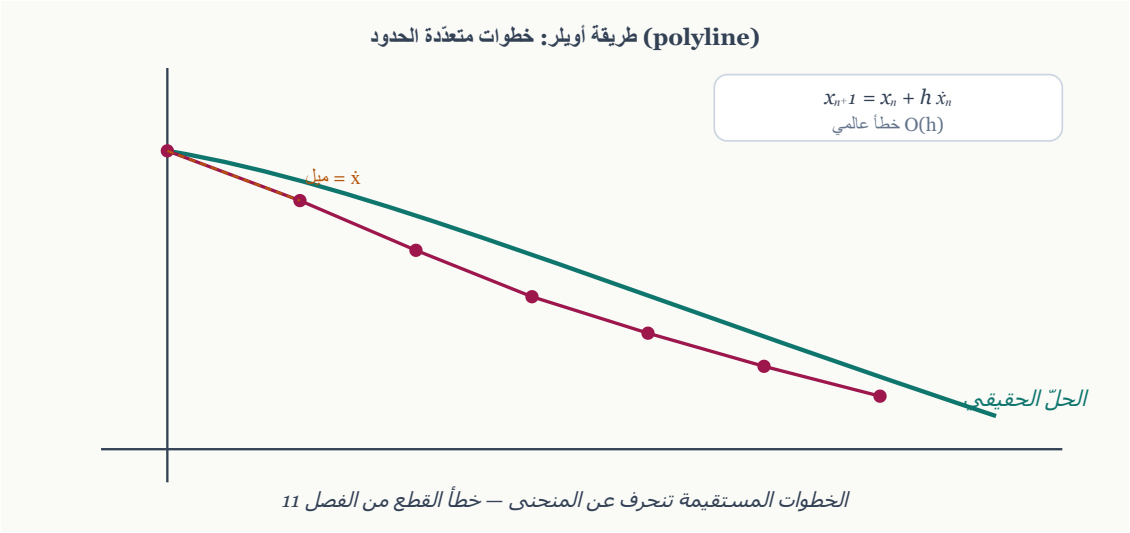
النظرية 1.3.12 (الخطأ): تقسيم الخطوة h ينقص الخطأ العالمي لأويلر بـ $O(h)$؛ لـ RK4 بـ $O(h^4)$.

جدول الرموز

الرمز	الاسم	المعنى
h	حجم الخطوة	دقّة/تكلفة
x_n	التقريب عند t_n	$x_n \approx x(t_n)$
RK4	رونج-كوتا 4	طريقة أعلى رتبة

رسم توضيحي

<figure> الشكل<figcaption> 2.12: أويلر يمشي بخطوات مستقيمة تتبع ميل $\dot{x}$ عند كل نقطة. الحلّ الحقيقي



شكل ٢.١٢: *
خطوات أويلر والميل المحليّ

(أخضر) ينحرف تدريجياً عن المضلّع الأحمر — خطأ القطع (من الفصل <figcaption>.(11 </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اختيار h كبيرة	خطأ/عدم استقرار	اضبط h تجريبياً
نسيان أنّ أويلر $O(h)$ فقط	أبطأ من RK4	استخدم RK4 للمسائل الناعمة
استخدام صريح على «متصلّبة»	قد ينفجر	استخدم ضمنياً
خلط الخطأ المحليّ/العالمي	مختلفان بالرتبة	المحلي $O(h^2)$، العالمي $O(h)$

أمثلة محلولة على الطرق العددية (15 مثالاً)

مثال (12.3-1).

- **المعطيات:** $\dot{x} = -x$، $x(0) = 1$، $h = 0.1$، خطوة واحدة.
- **المطلوب:** تقدير أويلر.
- **الحل:**

١. $x_1 = 1 + 0.1(-1) = 0.9$ (الحقيقي $e^{-0.1} \approx 0.905$). ■

- **النتيجة:** 0.9 (خطأ ≈ 0.005).
- **الربط بالذكاء الاصطناعي:** «خطوة تحديث واحدة» = تحديث SGD واحد — نفس البنية.

مثال (12.3-2).

- **المعطيات:** $\dot{x} = x$، $x(0) = 1$، $h = 0.1$، خطوتان.
- **المطلوب:** أويلر.
- **الحل:**

١. $x_1 = 1.1$، $x_2 = 1.1 + 0.1(1.1) = 1.21$. ■

- **النتيجة:** 1.21 (الحقيقي $e^{0.2} \approx 1.221$).
- **الربط بالذكاء الاصطناعي:** «نموّ مضلّل» — أويلر الصريح يبالغ في النموّ السريع (مثل خطوات تعليم كبيرة).

مثال (12.3-3).

- **المعطيات:** لوجستيك $\dot{x} = x(1 - x)$، $x_0 = 0.1$، $h = 0.2$.
- **المطلوب:** خطوة أويلر.
- **الحل:**

١. $x_1 = 0.1 + 0.2(0.1 \cdot 0.9) = 0.118$. ■

- **النتيجة:** 0.118.
- **الربط بالذكاء الاصطناعي:** «محاكاة ديناميكا الاحتمال» — أساس المحاكاة في التعزيزي.

مثال (12.3-4).

- **المعطيات:** $\dot{x} = -x$ بـ RK4 خطوة $h = 0.1$.
- **المطلوب:** قارن الدقّة بأويلر.
- **الحل:**

١. RK4 يجمع منحدرات عند نقاط عدّة $\Longrightarrow$ خطأ 10^{-5} $\sim$ مقابل 5×10^{-3} لأويلر. ■

- **النتيجة:** أدقّ بمرتين من الرتبة.
- **الربط بالذكاء الاصطناعي:** «تقييم متعدّد» = زيادة دقّة بتكلفة حسابية — مثل عينات متعدّدة.

مثال (3.12-5).

- **المعطيات:** قسّم h إلى النصف.
- **المطلوب:** كيف ينقص الخطأ؟
- **الحل:**

١. لأويلر العالمي $O(h)$ ينقص للنصف؛ لـ RK4 $O(h^4)$ ينقص لـ $1/16$. ■

- **النتيجة:** RK4 أسرع تحسّناً.
- **الربط بالذكاء الاصطناعي:** «تكلفة الدقّة» — توازن batch/epochs.

مثال (3.12-6).

- **المعطيات:** محليّ مقابل عالمي.
- **المطلوب:** اشرح الفرق.
- **الحل:**

١. محليّ لخطوة واحدة $O(h^2)$؛ يتراكم $1/h$ مرّة $\Longrightarrow$ عالمي $O(h)$. ■

- **النتيجة:** فرق رتبة.
- **الربط بالذكاء الاصطناعي:** «تراكم الخطأ» يشبه تراكم انحياز التقدير عبر الخطوات.

مثال (3.12-7).

- **المعطيات:** استقرار أويلر لـ $\dot{x} = \lambda x$.
- **المطلوب:** شرط الاستقرار.
- **الحل:**

١. $h < 2/|\lambda| \Longrightarrow |1 + h\lambda| < 1$ (لـ $\lambda < 0$). ■

- **النتيجة:** حدّ الخطوة.
- **الربط بالذكاء الاصطناعي:** «معدّل التعلّم الأقصى» = نصف قطر استقرار أويلر — نفس قيد GD!

مثال (3.12-8).

- **المعطيات:** أويلر الضمني (backward) $x_{n+1} = x_n + hf(x_{n+1})$.
- **المطلوب:** لماذا أكثر استقراراً؟
- **الحل:**

١. يحلّ معادلة ضمنية $\Rightarrow$ مستقرّ لـ h كبيرة على المتصلّبة. (stffi) ■

- **النتيجة:** A-stable.
- **الربط بالذكاء الاصطناعي:** «تحديث ضمني» = محسّنات المستوى الثاني (Newton) — استقرار بثمن حلّ معادلة.

مثال (12.3-9).

- **المعطيات:** طريقة المنتصف (midpoint) من رتبة 2.
- **المطلوب:** الخطوة.
- **الحل:**

١. $k_1 = hf_n$؛ $k_2 = hf(x_n + \frac{h}{2}, v_n + \frac{k_1}{2})$؛ $x_{n+1} = x_n + k_2$. ■

- **النتيجة:** $O(h^2)$.
- **الربط بالذكاء الاصطناعي:** «تقدير عند منتصف الخطوة» — نموذج لـ lookahead optimizers.

مثال (12.3-10).

- **المعطيات:** طريقة هون (Heun) = شبه منحرف.
- **المطلوب:** الصيغة.
- **الحل:**

١. $x_{n+1} = x_n + \frac{h}{2}(f_n + f(x_n + hf_n))$. ■

- **النتيجة:** رتبة 2.
- **الربط بالذكاء الاصطناعي:** «متوسّط ميلين» = نموذج لـ momentum المتوسط.

مثال (12.3-11).

- **المعطيات:** صريح مقابل ضمني.
- **المطلوب:** متى نفضّل الضمني؟
- **الحل:**

١. عند متصلّبة (eigenvalues كبيرة سالبة) الصريح ينهار؛ الضمني مستقرّ. ■

- **النتيجة:** حسب طيف النظام.
- **الربط بالذكاء الاصطناعي:** «هِسّية شديدة التكيّف» تستدعي محسّنات ضمنية. (ch11)

مثال (12-3.12).

- **المعطيات:** تراكم الخطأ عبر $N = T/h$ خطوة.
- **المطلوب:** الخطأ الكلّي.
- **الحل:**

١. $E_{\text{global}} \approx N \cdot E_{\text{local}} \propto (T/h) \cdot h^2 = Th = O(h)$. ■

- **النتيجة:** عالمي $O(h)$.
- **الربط بالذكاء الاصطناعي:** «عدد الخطوات × خطأ/خطوة» = تحليل عيّنات SGD. (ch11-7)

مثال (13-3.12).

- **المعطيات:** خطوة تكيّفية (embedded RK) مثل RKF45.
- **المطلوب:** الفكرة.
- **الحل:**

١. نركض ترتيبين؛ الفرق يُقدّر الخطأ فنضبط h تلقائياً. ■

- **النتيجة:** دقّة مضمونة بتكلفة أدنى.
- **الربط بالذكاء الاصطناعي:** «تعلّم معدّل تعلّم تكيّفي» (LR schedule) — نفس الفلسفة.

مثال (14-3.12).

- **المعطيات:** تقطيع GD كأويلر.
- **المطلوب:** اربط (15-2.12) رسمياً.
- **الحل:**

١. $\theta_{k+1} = \theta_k - \eta \nabla L(\theta_k)$ = أويلر لـ $\dot{\theta} = -\nabla L$ بخطوة η. ■

- **النتيجة:** GD = ODE مقطّعة.
- **الربط بالذكاء الاصطناعي:** «كلّ محسّن = طريقة عددية لمستمرّ» — بوصلة الفصل 6.12.

مثال (15-3.12).

- **المعطيات:** خطوات متعدّدة (Adams) مقابل خطوة واحدة.
- **المطلوب:** الميزة.
- **الحل:**

١. Adams-Basfhorth يستعيد مشتقّات سابقة ⟹ رتبة أعلى بأقلّ تكلفة/خطوة. ■

- **النتيجة:** كفاءة.
- **الربط بالذكاء الاصطناعي:** «إعادة استخدام حالات سابقة» = نموذج لـ momentum/Adam (لحظات تاريخية).

التعريف

dir="ltr"> <div
.$f(x^*) = 0$ fi **fixed** is x^* point A **stability). & point (Fixed 1.4.12 Definition
Stability $\dot{\xi} = J_f(x^*)\,\xi, \qquad J_f = \nabla f(x^*)$. :$x = x^* + \xi$ via x^* about $\dot{x} = f(x)$ Linearizing
$\Rightarrow \operatorname{Re}\lambda > 0$ any stable; asymptotically $\Rightarrow \operatorname{Re}\lambda < 0$ all :J_f of eigenvalues by determined is
unstable.

$$\dot{\xi} = \nabla f(x^*)\,\xi. \tag{3.12}$$

النظرية 1.4.12 (تصنيف): قيم ذاتية حقيقية متّفقة الإشارة ⟹ عقدة (node)؛ متباينة ⟹ سرج (saddle)؛ مركّبة ⟹ حلزون (spiral)؛ تخيّلية ⟹ مركز.

جدول الرموز

الرمز	الاسم	المعنى
x^*	نقطة ثابتة	$f(x^*)=0$
J_f	يعقوبية الحقل	تحكّم الاستقرار
λ	قيمة ذاتية	$\operatorname{Re}\lambda$ تحدّد الاستقرار

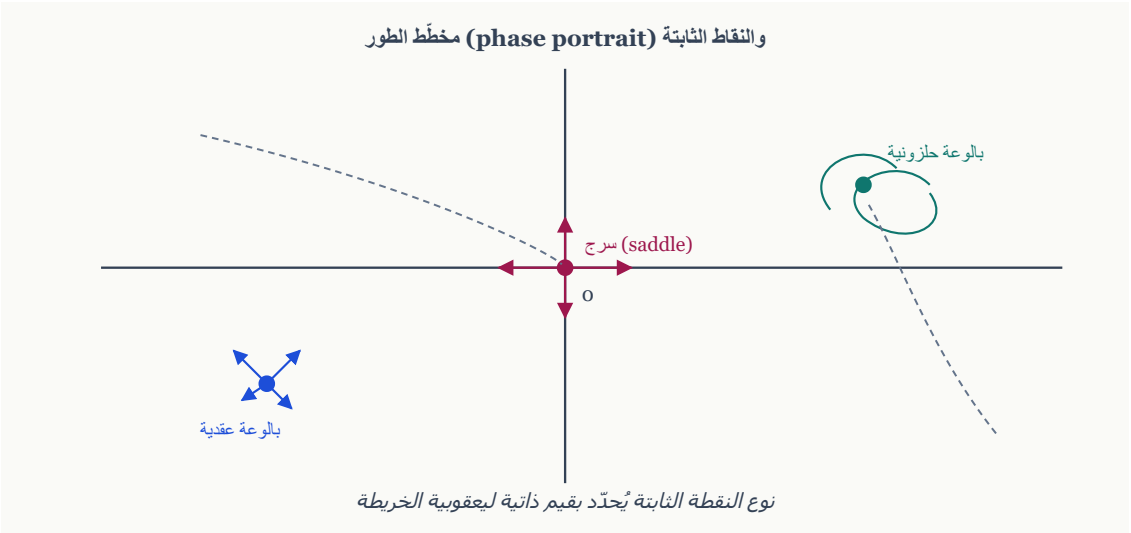
رسم توضيحي

<figure> الشكل<figcaption> 3.12: مخطّط الطور يُظهر ثلاثة أنواع: سرج (أحمر، انحراف+تقارب)، بالوعة حلزونية (أخضر)، بالوعة عقدية (أزرق). التصنيف يُحدّد بقيم ذاتية J_f.</figcaption></figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
الحكم بالاستقرار من f لا J	J هو من يقرّر	خطّط $\nabla f(x^*)$
تجاهل الجزء التخيّلي	حلزون لا مركز	فحص $\operatorname{Re}\lambda$
اعتبار كلّ سرج سيّئاً	قد يكون مستقرّ اتجاهياً	تحليل أبعاد
نسيان أنّ التحليل محلّي	بعيداً قد يختلف	أحواض جذب محلية

أمثلة محلولة على النقاط الثابتة والاستقرار (15 مثالاً)



شكل ٣.١٢: *
مخطّط طور بأنواع النقاط الثابتة

مثال (4.12-1).

- **المعطيات:** $\dot{x} = f(x)$، $f(x^*) = 0$.
- **المطلوب:** ما النقطة الثابتة؟
- **الحل:**

١. عند x^* المشتقّة صفر $\Longrightarrow$ لا حركة. ■

- **النتيجة:** توازن.
- **الربط بالذكاء الاصطناعي:** «نقطة ثابتة = حلّ مُثلّث» (تدرّج صفر).

مثال (4.12-2).

- **المعطيات:** $f(x) = x - x^3$.
- **المطلوب:** الثوابت واستقرارها.
- **الحل:**

١. $x^* = 0, \pm 1$؛ $f'(x) = 1 - 3x^2 \Longrightarrow f'(0) = 1 > 0$ (غير مستقر)، $f'(\pm 1) = -2 < 0$ (مستقر). ■

- **النتيجة:** 0 سرج، ± 1 مستقرّان.
- **الربط بالذكاء الاصطناعي:** «حلول محليّة متعدّدة» — نموذج لعدّة مُثلّثات.

مثال (12.4-3).

- **المعطيات:** لوجستيك $\dot{x} = rx(1 - x/K)$.
- **المطلوب:** استقرار 0 و K.
- **الحل:**

١. $f'(x) = r - 2rx/K$؛ $f'(0) = r > 0$ (غير مستقر)، $f'(K) = -r < 0$ (مستقر). ■

- **النتيجة:** السعة K جاذبة.
- **الربط بالذكاء الاصطناعي:** «حوض جذب» = منطقة تجذب التدريب نحو حلّ.

مثال (12.4-4).

- **المعطيات:** بندول $\ddot{\theta} = -\sin\theta$.
- **المطلوب:** الثوابت واستقرارها.
- **الحل:**

١. عند $\theta = 0$ (أسفل، مستقر)، $\theta = \pi$ (أعلى، غير مستقر). ■

- **النتيجة:** توازن مستقر/غير مستقر.
- **الربط بالذكاء الاصطناعي:** «توازنات مستقرة/هشّة» — نموذج لحلول شبكية مختلفة الجودة.

مثال (12.4-5).

- **المعطيات:** سرج-عقدة (saddle-node) $\dot{x} = \mu - x^2$.
- **المطلوب:** ماذا عند $\mu = 0$؟
- **الحل:**

١. لـ $\mu > 0$ ثابتان؛ عند $\mu = 0$ يلتقيان (تفرّع). ■

- **النتيجة:** تفرّع (bfiurcation).
- **الربط بالذكاء الاصطناعي:** «ظهور/اختفاء حلّ عند عتبة» — نموذج لظهور سلوك شبكي.

مثال (12.4-6).

- **المعطيات:** $\dot{x} = Ax$، $A = \begin{bmatrix} -1 & 2 \\ -2 & -1 \end{bmatrix}$.

- **المطلوب:** نوع النقطة.
- **الحل:**

١. $\lambda = -1 \pm 2i \implies$ حلزون جاذب. ■

- **النتيجة:** sink، spiral
- **الربط بالذكاء الاصطناعي:** «تذبذب مُخمَّد» — نموذج لديناميكا التعلّم المتذبذبة.

مثال (12.4-7).

- **المعطيات:** مركز x لـ $\dot{x} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$.
- **المطلوب:** استقرار؟
- **الحل:**

١. $\lambda = \pm i \implies$ مركز (مستقر محايداً لا جذباً). ■

- **النتيجة:** دوريّ لا يتقارب.
- **الربط بالذكاء الاصطناعي:** «حلقة حدّية» — نموذج لسلوك متكرّر لا يتقارب.

مثال (12.4-8).

- **المعطيات:** عقدة جاذبة $A = \operatorname{diag}(-2, -3)$.
- **المطلوب:** سلوك.
- **الحل:**

١. $\lambda = -2, -3$ سالبتان $\implies$ تقارب أسيّ أحاديّ الاتجاه. ■

- **النتيجة:** sink، node
- **الربط بالذكاء الاصطناعي:** «تقارب سلس» = تدريب مستقر دون تذبذب.

مثال (12.4-9).

- **المعطيات:** $V(x) = x^2$ لـ $\dot{x} = -x$.
- **المطلوب:** أثبت أنّها دالّة ليانوف.
- **الحل:**

١. $\dot{V} = 2x\dot{x} = -2x^2 < 0$ لـ $x \neq 0 \implies$ استقرار. ■

- **النتيجة:** ليانوف تُثبت الاستقرار بلا حلّ صريح.
- **الربط بالذكاء الاصطناعي:** «الخسارة كليانوف» — أساس 6.12.

مثال (10-4.12).

- **المعطيات:** نظام تدرّجي $\dot{x} = -\nabla U(x)$.
- **المطلوب:** هل دائماً يتقارب لأدنى؟
- **الحل:**

١. $\frac{d}{dt}U = -\|\nabla U\|^2 \leq 0$ ⟹ يتناقص حتى $\nabla U = 0$. ■

- **النتيجة:** يتقارب لمُثلّث.
- **الربط بالذكاء الاصطناعي:** «كلّ تدريب = نزول نحو أدنى» — أساس التحسين.

مثال (11-4.12).

- **المعطيات:** حوض جذب (basin).
- **المطلوب:** عرّفه.
- **الحل:**

١. مجموعة النقاط التي تنتهي عند نفس x^* تحت الديناميكا. ■

- **النتيجة:** منطقة جذب.
- **الربط بالذكاء الاصطناعي:** «حوض التعلّم» — يفسّر حساسية التهيئة للحلّ النهائي.

مثال (12-4.12).

- **المعطيات:** لوتكا-فولتيرا (فريسة-مفترس).
- **المطلوب:** نوع التوازن.
- **الحل:**

١. عند التوازن دورات مركزية (لا تقارب) — تذبذب دوريّ. ■

- **النتيجة:** cycles.
- **الربط بالذكاء الاصطناعي:** «ديناميكا تنافسية» — نموذج لأسواق/وكلاء متعدّدين.

مثال (13-4.12).

- **المعطيات:** تفرّع هوبف (Hopf).

- **المطلوب:** اشرح.
- **الحل:**

١. عند عتبة تدخل قيمة ذاتية عبر المحور التخيّلي $\Longrightarrow$ تولد حلقة حدّية. ■

- **النتيجة:** ظهور تذبذب.
- **الربط بالذكاء الاصطناعي:** «انهيار الاستقرار $\Longrightarrow$ سلوك دوري» — نموذج لتذبذب النموذج.

مثال (14-4.12).

- **المعطيات:** استقرار توازن تدريب الشبكة.
- **المطلوب:** اربط بـ J للخسارة.
- **الحل:**

١. عند مُثلّث، هِسّية $\nabla^2 L \succ 0$ (موجبة) $\Longrightarrow$ جاذب محلّي. ■

- **النتيجة:** استقرار محلّي.
- **الربط بالذكاء الاصطناعي:** «هِسّية موجبة = حوض» — يربط 4.12 بـ 4.11.

مثال (15-4.12).

- **المعطيات:** ديناميكا إجماع (consensus) $\dot{x}_i = \sum_j (x_j - x_i)$.
- **المطلوب:** التوازن وسلوكه.
- **الحل:**

١. التوازن عند x_i متساوية، المصفوفة Laplacian لها قيم سالبة عدا صفراً $\Longrightarrow$ إجماع مستقر. ■

- **النتيجة:** تتقارب كلّها لقيمة واحدة.
- **الربط بالذكاء الاصطناعي:** «طبقات التجميع/المتوسّط» = ديناميكا إجماع — أساس GNN والفلاتر.

التعريف

dir="ltr"> <div

Definition 1.5.12 (Heat / Wave / Laplace). The three classical PDEs on $u(x)$ or $u(x,t)$:

- **Heat (dffiusion):** $\partial_t u = \alpha \nabla^2 u$.
- **Wave:** $\partial_{tt} u = c^2 \nabla^2 u$.
- **Laplace / Poisson:** $\nabla^2 u = 0$ (or $= f$).

$$\partial_t u = \alpha \nabla^2 u. \tag{4.12}$$

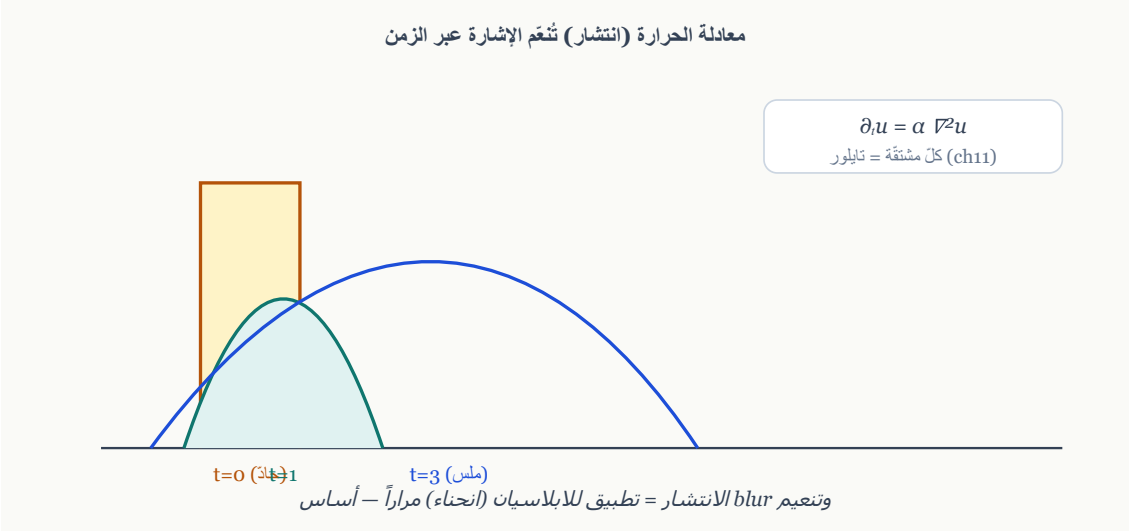
النظرية 1.5.12 (مبدأ أقصى/أسّ حراري): حلّ معادلة الحرارة لا يملك قيمة قصوى داخلية — يتبع «انسياب» من الحدود؛ وحلّها الأسّي هو نواة غاوسية.

جدول الرموز

الرمز	الاسم	المعنى
u	الحقل	دالة في المكان/الزمان
∇^2	اللابلاسيان	مجموع المشتقّات الثانية
α	معامل الانتشار	سرعة التلّس

رسم توضيحي

<figure> الشكل<figcaption> 4.12: معادلة الحرارة تحوّل نتوءاً حادّاً (t=0) إلى منحنى ملَس مع الزمن. كلّ خطوة



شكل ٤.١٢: *
معادلة الحرارة تنعّم إشارة

تطبّق اللابلاسيان (انحناء) — أساس الـ blur والتنعيم.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط ∇^2 مع ∇	لابلاسيان ليس تدرّجاً	مشتقّات ثانية
نسيان شروط الحدود	الحلّ غير فريد	حدد Dirichlet/Neumann
اعتبار الحرارة عكسيةً سهلة	غير محدّبة	مشكلة مطروحة سيّئة
تجاهل البعد الزمني	PDE متعدّدة	افصل متغيرات

أمثلة محلولة على المعادلات التفاضلية الجزئية (15 مثالاً)

مثال (12.5-1).

- **المعطيات:** $\partial_t u = \alpha u_{xx}$ على خطّ.
- **المطلوب:** تفسير.
- **الحل:**

١. معدّل التغيّر = α × الانحناء المحليّ. ■

- **النتيجة:** انتشار.
- **الربط بالذكاء الاصطناعي:** «تلطيف» (smoothing) = نواة التفاف — أساس الطبقات التلافيفية.

مثال (12.5-2).

- **المعطيات:** حالة سكون $\nabla^2 u = 0$.
- **المطلوب:** خصائص.
- **الحل:**

١. لا قيم قصوى داخلية؛ الحلّ يُحدَّد بحدوده. ■

- **النتيجة:** توازن توافقي.
- **الربط بالذكاء الاصطناعي:** «تكميل» (inpainting) = حلّ لابلاس بحدود معروفة.

مثال (12.5-3).

- **المعطيات:** موجية $u_{tt} = c^2 u_{xx}$.
- **المطلوب:** الحلّ العامّ.
- **الحل:**

١. $u(x,t) = F(x-ct) + G(x+ct)$ (موجتان متعاكستان). ■

- **النتيجة:** انتقال بسرعة c.
- **الربط بالذكاء الاصطناعي:** «انتشار إشارات» — نموذج لديناميكا التسلسلات.

مثال (5.12-4).

- **المعطيات:** فصل المتغيرات لـ حرارية على $[0, L]$.
- **المطلوب:** الصيغة.
- **الحل:**

١. $u = X(x)T(t)$، $\implies T'/T = \alpha X''/X = -\lambda$ أوضاع جيبية مُتضائلة. ■

- **النتيجة:** سلسلة فوريه.
- **الربط بالذكاء الاصطناعي:** «تحليل أوضاع» = أساس تحليل التردّدات (FFT).

مثال (5.12-5).

- **المعطيات:** الحلّ الأسّي للحرارية.
- **المطلوب:** عبّره.
- **الحل:**

١. $u(x,t) = \frac{1}{\sqrt{4\pi\alpha t}} e^{-x^2/(4\alpha t)}$. ■

- **نتيجة:** غاوسي يتمدّد.
- **الربط بالذكاء الاصطناعي:** «نواة غاوسية = انتشار» — تظهر في forwards dffiusion (7.12).

مثال (6.12-5).

- **المعطيات:** مبدأ الأقصى.
- **المطلوب:** استنتج.
- **الحل:**

١. لو بلغ القصوى داخلاً لكان $u_{xx} \leq 0$ متناقضاً مع $u_t = 0$ عند أقصى مستقرّ. ■

- **النتيجة:** القيمة القصوى على الحدود.
- **الربط بالذكاء الاصطناعي:** «لا ذروة داخلية» — يفسّر سلوك الحقول الملساء.

مثال (7.12-5).

- **المعطيات:** نواة الانتشار = غاوسي.
- **المطلوب:** اربط بـ (5-5.12).
- **الحل:**

١. الالتفاف بغاوس $e^{\alpha t \nabla^2}$ = يُلَيِّس الإشارة. ■

- **النتيجة:** blur غاوسي.

- **الربط بالذكاء الاصطناعي:** «التشويش الغاوسي المُضاف تدريجياً» هو انتشار (dffiusion) فعلياً (7.12).

مثال (8-5.12).

- **المعطيات:** شروط Dirichlet $u|_{\partial} = g$ مقابل Neumann $\partial_n u|_{\partial} = h$.
- **المطلوب:** الفرق.
- **الحل:**

١. Dirichlet يثبّت القيمة على الحدّ، Neumann يثبّت التدفّق (المشتقّة). ■

- **النتيجة:** نوعان من الحدود.

- **الربط بالذكاء الاصطناعي:** «قناع/حدود» = أنواع شروط في معالجة الصور.

مثال (9-5.12).

- **المعطيات:** بواسون $\nabla^2 u = f$.
- **المطلوب:** متى تُستخدم؟
- **الحل:**

١. عند وجود «مصدر» f (شحنة، كتلة). ■

- **النتيجة:** توازن بمنبع.

- **الربط بالذكاء الاصطناعي:** «حقل بمناطق اهتمام» — نموذج لخريطة حرارة بؤر.

مثال (10-5.12).

- **المعطيات:** الحرارية كـ blur.
- **المطلوب:** اربط بمعالجة الصور.
- **الحل:**

١. كلّ خطوة $u \leftarrow u + \alpha \nabla^2 u$ = التفاف بـ نواة تنعيم. ■

- **النتيجة:** blur تدريجي.

- **الربط بالذكاء الاصطناعي:** «طبقة تلافيفية = انتشار منفصل» — رؤية حاسوبية.

مثال (11-5.12).

- **المعطيات:** إزالة ضجيج بـ PDE.
- **المطلوب:** الطريقة.
- **الحل:**

١. حلّ عكسيّ للحرارية (مطروح سيّء) أو استخدم متباعدة total variation). ■

- **النتيجة:** تنقية.
- **الربط بالذكاء الاصطناعي:** «denoising» — سلف dffiusion الحديث (7.12).

مثال (12-5.12).

- **المعطيات:** انتشار-تفاعل (Turing).
- **المطلوب:** الفكرة.
- **الحل:**

١. تفاعل+انتشار يولّد أنماطاً (بقع) من اضطراب منتظم. ■

- **النتيجة:** أنماط.
- **الربط بالذكاء الاصطناعي:** «ظهور بنى» — نموذج لنشوء ميزات في الشبكات.

مثال (13-5.12).

- **المعطيات:** معادلة فوكر-بلانك للكثافة $p(x,t)$.
- **المطلوب:** اربط بالانتشار.
- **الحل:**

١. تصف تطوّر توزيع جسيمات تتبع SDE — PDE» لتوزيع» (7.12). ■

- **النتيجة:** ديناميكا التوزيع.
- **الربط بالذكاء الاصطناعي:** «كيف يتطوّر توزيع البيانات» — جوهر dffiusion.

مثال (14-5.12).

- **المعطيات:** اضمحلال وضع فوريه.

- **المطلوب:** سلوك كلّ تردّد.
- **الحل:**

١. الوضع e^{ikx} يضمحلّ بـ $e^{-\alpha k^2 t} \Longrightarrow$ الترددات العالية تختفي أوّلاً. ■

- **النتيجة:** تنعيم تردّدي.
- **الربط بالذكاء الاصطناعي:** «low-pass filtering» — يفسّر لماذا الانتشار يمسح التفاصيل.

مثال (15-5.12).

- **المعطيات:** لابلاسيان منفصل على شبكة.
- **المطلوب:** الصيغة.
- **الحل:**

١. $\nabla^2 u \approx u_{i+1} + u_{i-1} + u_{j+1} + u_{j-1} - 4u_{i,j}$ (جار الجذر). ■

- **النتيجة:** التفاف 3×3.
- **الربط بالذكاء الاصطناعي:** «نواة لابلاسيان» = مرشّح حواف كلاسيكي في الرؤية.

التعريف

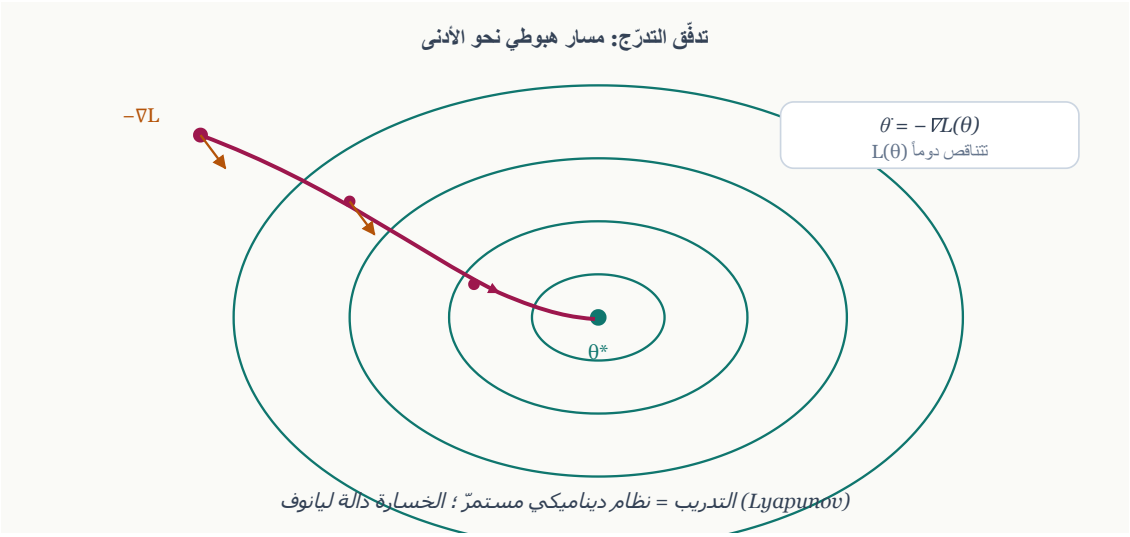
dir="ltr"> <div
the is descent gradient by model a Training **flow).** **(Gradient 1.6.12 Definition**
loss the flow this Along $\dot{\theta} = -\nabla L(\theta)$. :**flow gradient** continuous-time the of discretization
$\frac{d}{dt} L(\theta(t)) = \langle \nabla L, \dot{\theta} \rangle = -\|\nabla L\|^2 \leq 0$. monotonically: decreases

$$\dot{\theta} = -\nabla L(\theta), \qquad \frac{dL}{dt} = -\|\nabla L\|^2. \tag{5.12}$$

النظرية 1.6.12 (ليانوف): $L(\theta)$ نفسها دالّة ليانوف — تنخفض دوماً وتستقرّ عند نقطة حرجة. الانتقال المنفصل (خطوات محدودة) قد يتجاوز الحدّ الأدنى أو يعلق في سرج (تُنقذه الضوضاء).

جدول الرموز

الرمز	الاسم	المعنى
$\theta(t)$	مسار المعاملات	تطوّر التدريب
L	الخسارة	دالّة ليانوف
$\|\nabla L\|^2$	معدّل الهبوط	سرعة التقارب



شكل ٥.١٢: *
تدفّق تدرّجي هابط

رسم توضيحي

<figure> الشكل<figcaption> 5.12: مسار $\theta(t)$ يهبط عبر خطوط متساويات الخسارة نحو الأدنى θ^*. اتجاه الخطوة هو $-\nabla L$ (برتقالي)؛ الخسارة تَنقص رتيباً (ليانوف).</figcaption> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
اعتبار GD تتقارب دائماً لأدنى عامّ	قد تعلق في سرج/محلّي	تفحص المشهد
نسيان أثر الخطوة المنفصلة	المستمرّ يختلف تماماً flow gradient ≠ GD	
تجاهل الضجيج في SGD	يغير الديناميكا	ضوضاء + flow = SGD
خلط تقارب نقطة بحوض	محلّي vs عامّ	حوض جذب محلّي

أمثلة محلولة على النظم الديناميكية والتعلّم (15 مثالاً)

مثال (12.6-1).

- **المعطيات:** $\dot{\theta} = -\nabla L$.
- **المطلوب:** عرّف تدفّق التدرّج.
- **الحل:**

١. مسار مستمرّ «ينزلق» نحو أدنى L. ■

- **النتيجة:** هبوط رتيب.
- **الربط بالذكاء الاصطناعي:** «النموذج = نظام هابط» — القلب النظري للتحسين.

مثال (12.6-2).

- **المعطيات:** أثبت $dL/dt \le 0$.
- **المطلوب:** اشتقّ.
- **الحل:**

١. السلسلة: $\dot{L} = \nabla L^\top \dot{\theta} = -\|\nabla L\|^2 \le 0$. ■

- **النتيجة:** ليانوف مُثبت.
- **الربط بالذكاء الاصطناعي:** «الخسارة تَنقص كلّ خطوة» = ضمان التدريب (نظرياً).

مثال (12.6-3).

- **المعطيات:** GD المنفصل $\theta_{k+1} = \theta_k - \eta \nabla L$.
- **المطلوب:** اربطه بـ أويلر (12.3).
- **الحل:**

١. = أويلر للمستمرّ بخطوة η. ■

- **النتيجة:** GD = ODE مقطّعة.
- **الربط بالذكاء الاصطناعي:** «كلّ محسّن = طريقة عددية» — بوصلة التحسين.

مثال (12.6-4).

- **المعطيات:** SGD كـ flow gradient + ضوضاء.
- **المطلوب:** الصيغة.
- **الحل:**

١. $\dot{\theta} = -\nabla L(\theta) + \sigma(\theta, t)\,\xi(t)$ (SDE). ■

- **النتيجة:** flow عشوائيّ.
- **الربط بالذكاء الاصطناعي:** «SGD = تدفّق مُضطرب» — يشرح الهروب من السرج.

مثال (12.6-5).

- **المعطيات:** زخم (heavy ball) $\ddot{\theta} + \gamma\dot{\theta} = -\nabla L$.

- **المطلوب:** اربطه بنظام من الدرجة الثانية.
- **الحل:**

١. تفاضل زمنيّ ثانٍ بماصّة γ — يكتسب زخماً. ■

- **النتيجة:** ODE مرتبة 2.
- **الربط بالذكاء الاصطناعي:** «momentum» = قصور ذاتي يسرّع التقارب.

مثال (6-6.12).

- **المعطيات:** نيستيروف المُسرّع.
- **المطلوب:** علاقته بالزخم.
- **الحل:**

١. يقارب عند «نقطة تطلّع» مستقبلية $\Rightarrow$ أسرع (تقارب $O(1/k^2)$). ■

- **النتيجة:** تسريع.
- **الربط بالذكاء الاصطناعي:** «التطلّع للمستقبل» = نيستيروف — معيار التسريع.

مثال (7-6.12).

- **المعطيات:** هروب من سرج بالضوضاء.
- **المطلوب:** كيف؟
- **الحل:**

١. الاتجاه السالب-المعياري (instability) يضخّم الضجيج $\Rightarrow$ خروج من السرج. ■

- **النتيجة:** الضجيج منقذ.
- **الربط بالذكاء الاصطناعي:** «لماذا SGD أفضل من «GD — الضجيج يكسر السروج.

مثال (8-6.12).

- **المعطيات:** حوض جذب لمُثلّث.
- **المطلوب:** ما يحدّده؟
- **الحل:**

١. التهيئة θ_0 ضمن الحوض $\Rightarrow$ تنتهي عند نفس الحلّ. ■

- **النتيجة:** حساسية للتهيئة.
- **الربط بالذكاء الاصطناعي:** «حوض التعلّم» يفسّر تباين النتائج بتهيئة مختلفة.

مثال (12.6-9).

- **المعطيات:** حادّة مقابل تسطّح المُثلّث.
- **المطلوب:** علاقتها بالتعميم.
- **الحل:**

١. هِسّية مسطّحة (قيم ذاتية صغيرة) $\perp$ تعميم أفضل غالباً. ■

- **النتيجة:** تسطّح = تعميم.
- **الربط بالذكاء الاصطناعي:** «Sharpness-Aware Minimization» تحسّن التعميم عبر المشهد.

مثال (12.6-10).

- **المعطيات:** ديناميكا رأي/إجماع.
- **المطلوب:** اربط بـ (12.4-15).
- **الحل:**

١. كلّ عقدة تقترب من جيرانها $\Longrightarrow$ إجماع = تدفّق تدرّجي على Laplacian. ■

- **النتيجة:** توافق.
- **الربط بالذكاء الاصطناعي:** «تجميع GNN» = انتشار معلومات ديناميكي.

مثال (12.6-11).

- **المعطيات:** شبكة هوبفيلد.
- **المطلوب:** ديناميكيتها.
- **الحل:**

١. $\dot{s}_i = -\sum_j w_{ij} s_j$ تنزل طاقة $E = -\frac{1}{2} s^\top W s$ $\Longrightarrow$ تستقرّ عند ذاكرة. ■

- **النتيجة:** طاقة تَنقص.
- **الربط بالذكاء الاصطناعي:** «شبكات تذكّر» = نظام ديناميكي بطاقة ليانوف.

مثال (12.6-12).

- **المعطيات:** ليانوف لـ GD.
- **المطلوب:** أثبت التقارب.
- **الحل:**

١. L تَنقص رتيباً ومحدودة أسفل $\Longrightarrow$ تتقارب لـ $\nabla L = 0$. ■

- **النتيجة:** تقارب نظري.
- **الربط بالذكاء الاصطناعي:** «لماذا يتقارب التدريب» — ضمان أساسي.

مثال (13-6.12).

- **المعطيات:** زمن التقارب لـ $\nabla^2 L \succ \mu I$.
- **المطلوب:** قدّره.
- **الحل:**

١. المستمرّ يتقارب أُسّياً بـ معدّل μ (محدّب مكتنز). ■

- **النتيجة:** $O(e^{-\mu t})$.
- **الربط بالذكاء الاصطناعي:** «سرعة التقارب تتبع التكيّف» — يربط بـ 6.11.

مثال (14-6.12).

- **المعطيات:** حدّ متوسط الحقل (mean-field).
- **المطلوب:** الفكرة.
- **الحل:**

١. مع عرض$\to\infty$، معاملات الشبكة تتبع ODE حتمية (لا ضجيج). ■

- **النتيجة:** تحديد حتمي.
- **الربط بالذكاء الاصطناعي:** متوسط/NTK» الحقل» يحوّل الشبكة لنظام ODE (ch11.11-7).

مثال (15-6.12).

- **المعطيات:** الشبكة تحوّل البيانات كتدفّق.
- **المطلوب:** اربط.
- **الحل:**

١. كلّ طبقة = خطوة تدفّق يحوّل توزيع الدخل نحو قابل للفصل. ■

- **النتيجة:** تدفّق تحويلي.
- **الربط بالذكاء الاصطناعي:** «تحويل الميزات تدريجياً» = أساس learning، representation

النظريات والصيغ

dir="ltr"> <div

a defines ODE Neural A **SDE). Dffiusion & ODE (Neural 1.7.12 Theorem**
(VP) Variance-Preserving A $\frac{dz}{dt} = f_\theta(z,t), \quad z(0) = z_0$. by model continuous-depth
(Anderson) SDE reverse-time with $dx = -\frac{1}{2}\beta(t)\,x\,dt + \sqrt{\beta(t)}\,dW$, SDE forward has dffiusion
$dx = \big[-\frac{1}{2}\beta(t)x - \beta(t)\,\nabla_x \log p_t(x)\big]dt + \sqrt{\beta(t)}\,d\bar{W}$.

$$\text{ODE: Neural} \dot{z} = f_\theta(z,t); \qquad \text{reverse: VP-SDE} dx = \big[-\tfrac{1}{2}\beta x - \beta \nabla \log p\big]dt + \sqrt{\beta}\,d\bar{W}. \tag{6.12}$$

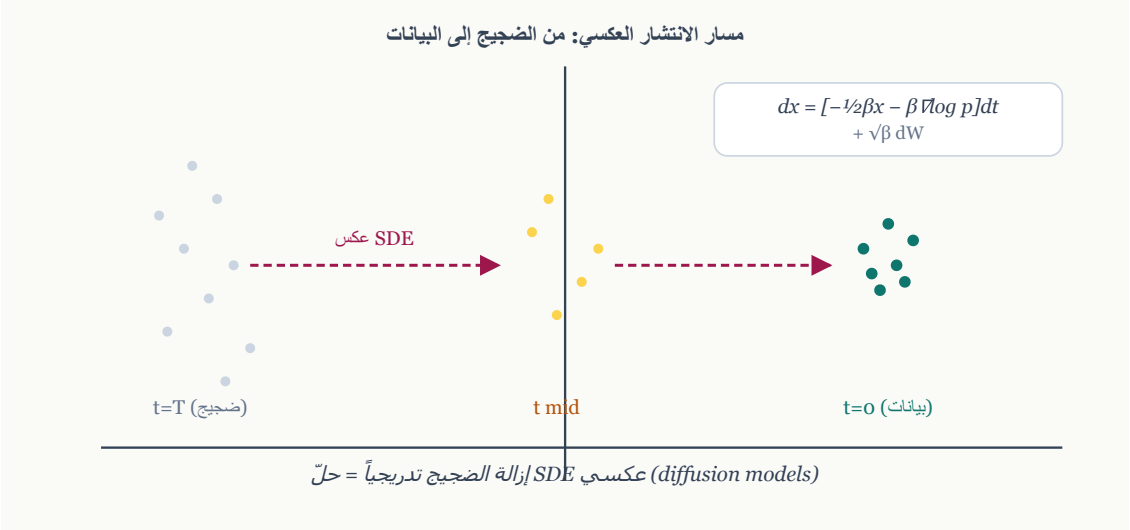
النظرية 1.7.12 (الطريقة المُلحَقة/Adjoint): تفاضل ODE Neural يُحسب بتكامل عكسي لمعادلة مُلحَقة — ذاكرة $O(1)$ لا $O(\text{depth})$.

جدول الرموز

الرمز	الاسم	المعنى
f_θ	شبكة التدفّق	تحكم dz/dt
$\beta(t)$	جدول الضجيج	سرعة الانتشار
$\nabla \log p$	السكور	يقود الإزالة العكسية

رسم توضيحي

<figure> الشكل<figcaption> 6.12: مسار الانتشار العكسي يبدأ من ضجيج (t=T) وينتهي عند بيانات (t=0).



شكل ٦.١٢: *
مسار الانتشار العكسي من الضجيج للبيانات

القيادة بواسطة السكور $\nabla \log p_t$ عبر SDE عكسي — قلب نماذج التوليد الحديثة.<figcaption/> </figure>

أخطاء شائعة

الخطأ	لماذا خطأ	التصحيح
خلط المستقبل بالماضي في SDE	الاتجاه يقلب الإشارة	استخدم صيغة أندرسون العكسية
نسيان أنّ ODE Neural «بلا عمق»	عمقه = الزمن	الحلّ العددي يحدّه
اعتبار السكور معروفاً	يُعلَّم بـ matching score	تعلّم $\nabla \log p$
تجاهل استقرار أويلر-مارویاما	قد ينفجر	اضبط خطوة التقدير

أمثلة محلولة على التطبيقات الحديثة (15 مثالاً)

مثال (12.7-1).

- **المعطيات:** ODE Neural $\dot{z} = f_\theta(z, t)$ من z_0.
- **المطلوب:** ما «العمق» هنا؟
- **الحل:**

١. العمق = الزمن T؛ الحلّ $z(T) = z_0 + \int_0^T f_\theta \, dt$. ■

- **النتيجة:** عمق مستمرّ.
- **الربط بالذكاء الاصطناعي:** «شبكة لا نهائية الطبقات» — وفّر ذاكرة عبر solver ODE.

مثال (12.7-2).

- **المعطيات:** التفاضل المُلحَق (adjoint).
- **المطلوب:** كيف يتفادى التكلفة؟
- **الحل:**

١. يكامل معادلة مُلحَقة عكسية $\Longrightarrow$ ذاكرة ثابتة بغضّ النظر عن T. ■

- **النتيجة:** $O(1)$ ذاكرة.
- **الربط بالذكاء الاصطناعي:** «تدريب نموذج مستمرّ» بلا تخزين كلّ خطوة — مفتاح Neural ODE.

مثال (12.7-3).

- **المعطيات:** تدفّق تطبيعي مستمرّ (CNF).
- **المطلوب:** كيف يُعلَّم؟
- **الحل:**

١. نغيّر p_0 (ضجيج) إلى p_1 (بيانات) بتدفّق، نُعلّم بـ Jacobian log-det (قاعدة 5.9). ■

- **نتيجة:** نموذج كثافة.
- **الربط بالذكاء الاصطناعي:** «تعيين بيانات↔ضجيج» — أساس التوليد الاحتمالي.

مثال (12.7-4).

- **المعطيات:** SDE أمامي VP.
- **المطلوب:** اكتبه.
- **الحل:**

١. $dx = -\frac{1}{2}\beta(t)x\,dt + \sqrt{\beta(t)}\,dW$. ■

- **النتيجة:** إضافة ضجيج تدريجي.
- **الربط بالذكاء الاصطناعي:** «عملية التشويش» = تدريب dffiusion.

مثال (12.7-5).

- **المعطيات:** عند $t = T$ كبيرة، $x_T \approx \mathcal{N}(0, I)$.
- **المطلوب:** لماذا؟
- **الحل:**

١. الحلّ $x_t = e^{-\frac{1}{2}\int\beta} x_0 + \int \sqrt{\beta}\,dW \Longrightarrow$ التباين يتراكم للضجيج. ■

- **نتيجة:** نهاية ضجيج محض.
- **الربط بالذكاء الاصطناعي:** «العيّنة المولّدة تبدأ من ضجيج» — dffiusion. in sampling

مثال (12.7-6).

- **المعطيات:** SDE عكسي لإزالة الضجيج.
- **المطلوب:** اكتبه.
- **الحل:**

١. $dx = [-\frac{1}{2}\beta x - \beta\nabla \log p_t]dt + \sqrt{\beta}\,d\bar{W}$ (من 12.6). ■

- **نتيجة:** يقوده السكور.
- **الربط بالذكاء الاصطناعي:** «الخطوة العكسية» = توليد صورة من ضجيج.

مثال (12.7-7).

- **المعطيات:** مطابقة السكور (score matching).
- **المطلوب:** ما المُعلَّم؟
- **الحل:**

١. نعلّم شبكة $s_\theta \approx \nabla_x \log p_t(x)$ عبر فقدان سكور. ■

- **نتيجة:** تقدير السكور.
- **الربط بالذكاء الاصطناعي:** «score» = مشتقّة لوغ-كثافة» (tie 11.7-8) يقود diffusion.

مثال (12.7-8).

- **المعطيات:** توبيدي (Tweedie) لإزالة الضجيج.
- **المطلوب:** الصيغة.
- **الحل:**

١. $\mathbb{E}[x_0|x_t] = x_t + \beta_t \nabla \log p_t(x_t)$ (من 11.7-12). ■

- **نتيجة:** خطوة تنظيف.
- **الربط بالذكاء الاصطناعي:** «تقدير البيانات النظيفة» = جوهر خطوة denoising.

مثال (12.7-9).

- **المعطيات:** أويلر-ماروياما لـ SDE.
- **المطلوب:** الصيغة.
- **الحل:**

١. $x_{n+1} = x_n + f_n h + g_n \sqrt{h}\, Z_n,\ Z_n \sim \mathcal{N}(0,1)$. ■

- **نتيجة:** تقدير عشوائيّ.
- **الربط بالذكاء الاصطناعي:** «توليد عيّنة» = خطوات عشوائية عكسية.

مثال (12.7-10).

- **المعطيات:** معادلة فوكر-بلانك للكثافة.

- **المطلوب:** اربط بـ (13-5.12).
- **الحل:**

١. تصف $\partial_t p = \nabla \cdot (\frac{1}{2}\beta x p + \beta p \nabla \log p)$ — تطوّر التوزيع. ■

- **نتيجة:** PDE للتوزيع.
- **الربط بالذكاء الاصطناعي:** «كيف يتطوّر توزيع العيّنات» — مقياس توليد dffiusion.

مثال (11-7.12).

- **المعطيات:** لانغفين MCMC كـ SDE.
- **المطلوب:** الصيغة.
- **الحل:**

١. $x_{k+1} = x_k + \eta \nabla \log p(x_k) + \sqrt{2\eta}\, Z$ (من 11.7-7). ■

- **نتيجة:** مشي عشوائي موجّه.
- **الربط بالذكاء الاصطناعي:** «أخذ عيّنات من التوزيع» = تقدير مونت كارلو عبر SDE.

مثال (12-7.12).

- **المعطيات:** مطابقة التدفّق (flow matching).
- **المطلوب:** الفكرة.
- **الحل:**

١. نعلّم حقل سرعة v_θ يطابق مسار نقل أمثل من ضجيج لبيانات. ■

- **نتيجة:** بديل لـ dffiusion.
- **الربط بالذكاء الاصطناعي:** «تدفّق مستمرّ للتوليد» — أسرع من SDE أحياناً.

مثال (13-7.12).

- **المعطيات:** ODE احتمالي التدفّق (probability flow).
- **المطلوب:** ما ميزته؟
- **الحل:**

١. مسار حتميّ بنفس هندسة السكور (بلا ضجيج) $\Longrightarrow$ توليد حتميّ قابل للتحكّم. ■

- **نتيجة:** sampling. deterministic
- **الربط بالذكاء الاصطناعي:** «توليد حتميّ» — استقرار أعلى من SDE.

مثال (12.7-14).

- **المعطيات:** حفظ مقابل انفجار التباين في SDE.
- **المطلوب:** الفرق.
- **الحل:**

١. VP تحفظ تباين الضجيج بـ β مضبوط؛ VE يتركه ينفجر (يتطلّب جدولة). ■

- **نتيجة:** استقرار الجدولة.
- **الربط بالذكاء الاصطناعي:** «جدولة الضجيج» = hyperparameter حاسم في dffiusion.

مثال (12.7-15).

- **المعطيات:** نواة التماس العصبية كـ limit.
- **المطلوب:** اربط بـ ODE.
- **الحل:**

١. عند العرض اللانهائي، تطوّر المعاملات ODE حتميّ (NTK، 11.7-11) $\Longrightarrow$ تجمّد التدريب. ■

- **نتيجة:** تحديد حتمي.
- **الربط بالذكاء الاصطناعي:** «لماذا الشبكات العميقة تتعلّم كنواة» = نظام ODE عند العرض اللانهائي.

خيط الفصل

١. **ODE (12.2):** $\dot{x} = f$ مع شرط بداية؛ الوجود/الوحيدة بـ Lipschitz — لغة «التطوّر الزمني».

٢. **الطرق العددية (12.3):** أويلر (خلف (!GD وRK4 تُقطّع الزمن؛ خطأ $O(h)$ لأويلر.

٣. **التحليل الكيفي (12.4):** النقاط الثابتة والاستقرار عبر J_f — يفسّر تقارب/علوق التدريب.

٤. **PDE (12.5):** الحرارية = انتشار = أساس blur و dffiusion (نواة غاوسية).

٥. **النظم والتعلّم (12.6):** $\dot{\theta} = -\nabla L$ تدفّق تدرّجي؛ الخسارة ليانوف تتناقص.

٦. **التطبيقات (12.7):** ODE Neural و Dffiusion/SDE — التوليد الحديث = حلّ SDE عكسي بقيادة السكور.

جدول الجسور

مفهوم هذا الفصل	استخدامه لاحقاً
GD = أويلر (3.12)	كلّ نظريات التحسين (الجزء 4)
ليانوف (6.12)	تقارب التعلّم، الاستقرار
السكور/SDE (7.12)	dffiusion، بايز، أخذ العيّنات (الجزء 3، 7)
نقطة ثابتة (4.12)	توازنات الشبكات، NTK
لابلاسيان/PDE (5.12)	معالجة الإشارات، الرؤية
ODE Neural (7.12)	نماذج التدفّق، التوليد

١. حلّ $\dot{x} = 3x$، $x(0) = 2$ وحدّد سلوك $t \to \infty$.

٢. أثبت بيكار-ليندلوف لـ $\dot{x} = f(x)$ Lipschitz محليّاً.

٣. لـ $\dot{x} = x^{1/3}$، $x(0) = 0$، أعطِ حلّين مختلفين (فقدان الوحيدة).

٤. خطوة أويلر واحدة لـ $\dot{x} = -2x$، $x(0) = 1$، $h = 0.1$ (قارن بـ $e^{-0.2}$).

٥. اشتقق شرط الاستقرار $|1 + h\lambda| < 1$ لأويلر على $\dot{x} = \lambda x$.

٦. لـ لوجستيك، صنّف النقاط $0, K$ باليعقوبية.

٧. أثبت أنّ $V(x) = x^2$ ليانوف لـ $\dot{x} = -x$.

٨. حلّ $\ddot{x} = -\omega^2 x$ وحدّد أنّه مركز (لا جاذب).

٩. اكتب معادلة الحرارة الأسّية (نواة غاوسية) وفسّر انتشارها.

١٠. بفصل المتغيرات، أثبت أنّ أوضاع الحرارية تضمحلّ كـ $e^{-\alpha k^2 t}$.

١١. أثبت $dL/dt = -\|\nabla L\|^2$ لتدفّق التدرّج.

١٢. اربط GD المنفصل بـ أويلر (اكتب الصيغتين).

١٣. لـ SGD عبر SDE: $\dot{\theta} = -\nabla L + \sigma\xi$، ناقش دور الضجيج في الهروب من السرج.

١٤. اكتب SDE أمامي VP وعكسي (صيغة أندرسون) مع السكور.

١٥. اشتقّ Tweedie $\mathbb{E}[x_0|x_t] = x_t + \beta_t \nabla \log p_t(x_t)$ (اربط بـ ch11).

١٦. صفّ طريقة المُلحَقة (adjoint) لـ ODE Neural ولماذا ذاكرتها $O(1)$.

١٧. عرّف حوض الجذب واربطه بحساسية التهيئة في التدريب.

١٨. لـ $A = \text{diag}(-1, -2)$، حدّد نوع النقطة الثابتة للنظام $\dot{x} = Ax$.

١٩. اشرح لماذا «الحرارية العكسية مطروحة سيّئة» (مبدأ الأقصى) وعلاقتها بـ denoising.

٢٠. تحدٍّ تركيبي: «لماذا التدريب يتقارب؟» — اجمع: أويلر=GD لمستمرّ (3.12)، الخسارة ليانوف (6.12)، والنقطة الثابتة مُثلّث محلّي مستقرّ بـ $H \succ 0$ (4.4,11.12) — واذكر متى يفشل (سرج، تكيّف سيّئ من 6.11).

- **ODE (1.12):** $\dot{x} = f(t,x)$ مع $x(t_0) = x_0$؛ الوجود/الوحيدة بـ Lipschitz (بيكار-ليندلوف).
- **الطرق (2.12):** أويلر $x_{n+1} = x_n + h\dot{x}_n$ (عالمي $O(h)$)؛ RK4 أعلى رتبة.
- **الاستقرار (3.12):** $\dot{\xi} = \nabla f(x^*)\xi$؛ $\operatorname{Re}\lambda < 0 \Rightarrow$ مستقرّ.
- **PDE (4.12):** الحرارية $\partial_t u = \alpha \nabla^2 u$، حلّها أسّ غاوسي؛ مبدأ الأقصى.
- **تدفّق التدرّج (5.12):** $\dot{\theta} = -\nabla L$، $dL/dt = -\|\nabla L\|^2$ (ليانوف)؛ GD = أويلر له.
- **التطبيقات (6.12):** Neural ODE $\dot{z} = f_\theta(z,t)$؛ VP-SDE أمامي/عكسي بقيادة السكور $\nabla \log p$ (أساس dffiusion).

الرمز	المعنى	أين عُرّف
$\dot{x}$	المشتقّة الزمنية	(1.12)
h	حجم الخطوة	(2.12)
J_f	يعقوبية الحقل	(3.12)
$\nabla^2 u$	اللابلاسيان	(4.12)
$L(\theta)$	الخسارة (ليانوف)	(5.12)
$\nabla \log p$	السكور	(6.12)

١. S. Strogatz, (2018). *Nonlinear Chaos and Dynamics*, 2nd ed., CRC Press — التحليل الكيفي والنقاط الثابتة.

٢. R. DiPrima, & W. Boyce, (2017). *Elementary Differential Equations*, 11th ed., Wiley — ODE وحلولها.

٣. R. LeVeque, (2007). *Finite Difference Methods for ODE/PDE*, SIAM — الطرق العددية والاستقرار.

٤. L. Evans, (2010). *Partial Differential Equations*, 2nd ed., AMS — الحرارية/الموجية/اللابلاسيان.

٥. B. Anderson, (1982). *Reverse-time diffusion equation models* (stochastic processes) — أساس SDE العكسي.

٦. R. Chen, et al. (2018). *Neural Ordinary Differential Equations* (NeurIPS) — تدفّق عصبي مستمرّ.

٧. S. Ermon, & Y. Song, (2019); J. Ho, et al. (2020), dffiusion/SDE — DDPM والسكور $(\nabla \log p)$.

٨. L. Bottou, (2010). *Large-Scale Machine Learning with SGD* — GD كديناميكا عشوائية؛ يربط بـ 6.12.

٩. N. Qian, (1999); I. Sutskever, et al. (2013) — الزخم/نيستيروف كـ ODE من الدرجة الثانية.